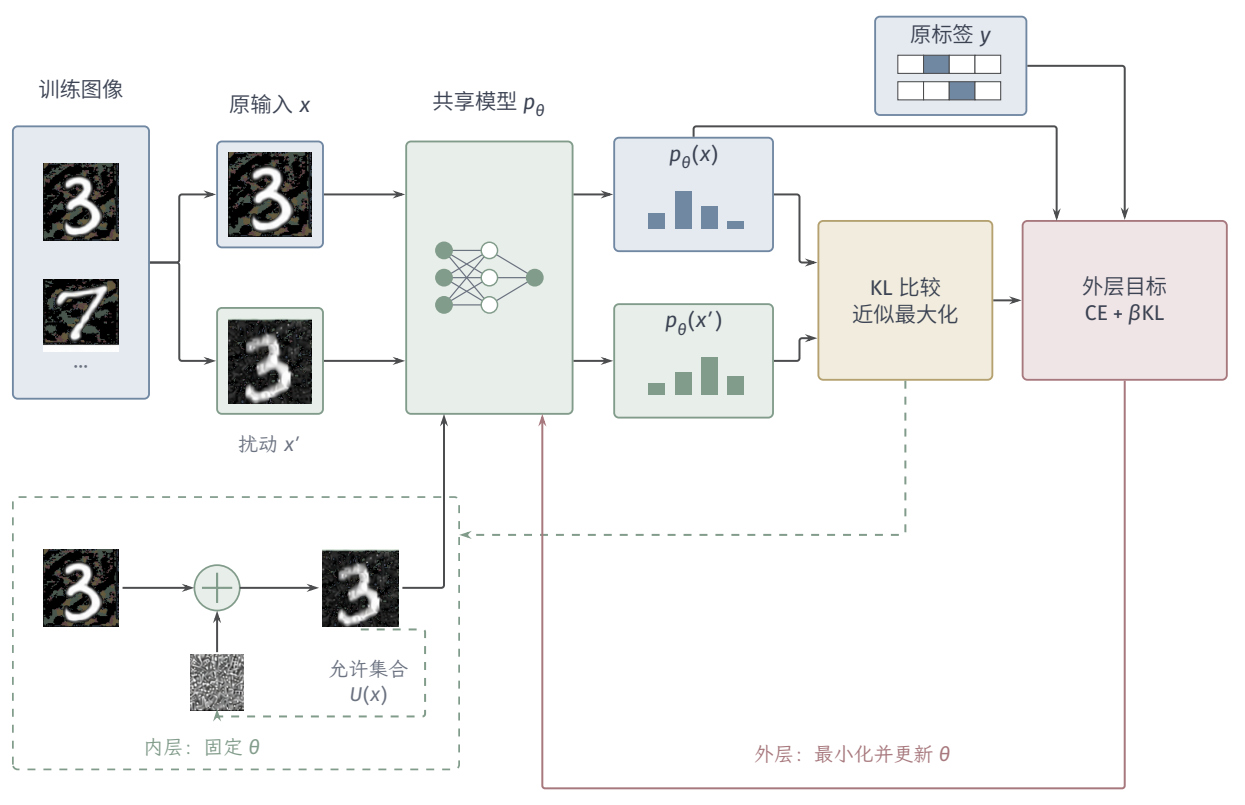

训练图像
...
原输入 $x$
扰动 $x'$
共享模型 $p_\theta$
$p_\theta(x)$
$p_\theta(x')$
原标签 $y$
KL 比较
近似最大化
外层目标
CE + $\beta$KL
允许集合
$U(x)$
内层：固定 $\theta$
外层：最小化并更新 $\theta$