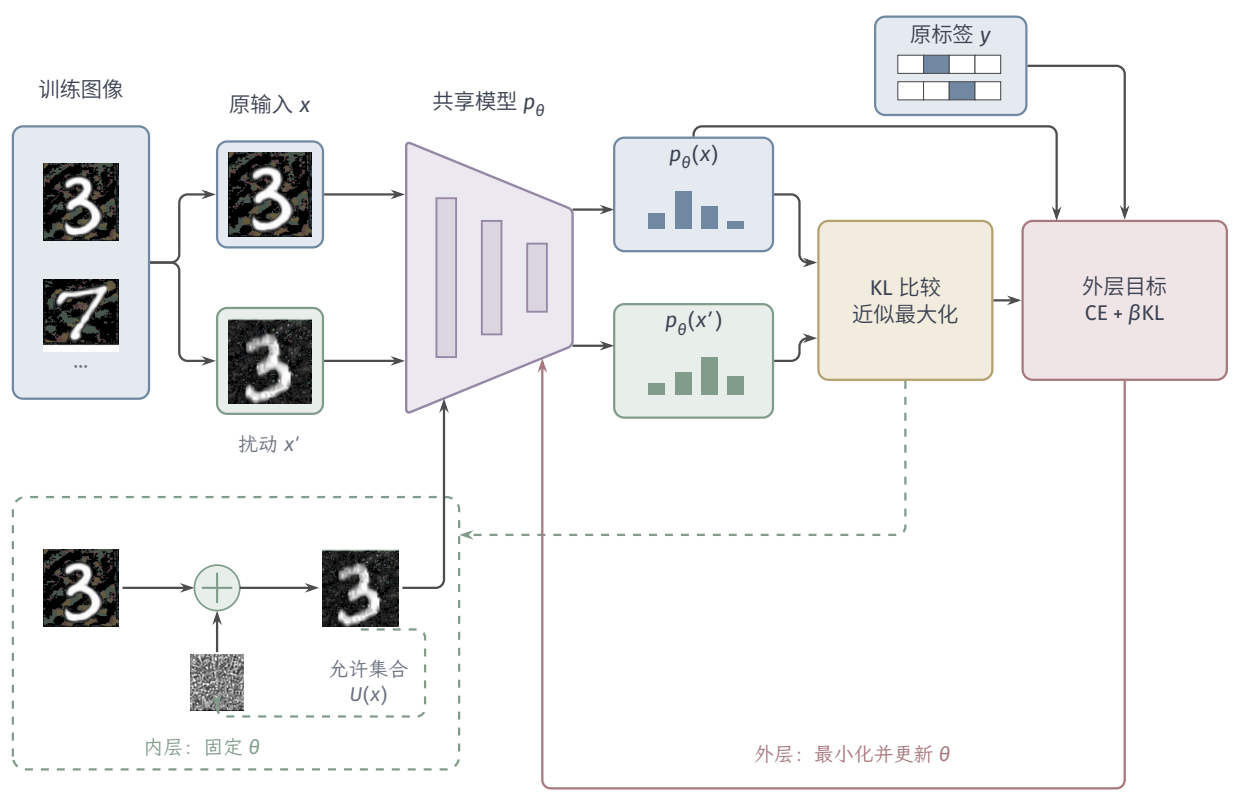

训练图像
...
原输入 x
扰动 x′
共享模型 p_θ
$p_\theta(x)$
$p_\theta(x')$
原标签 y
KL 比较
近似最大化
外层目标
CE + βKL
允许集合
U(x)
内层：固定 θ
外层：最小化并更新 θ