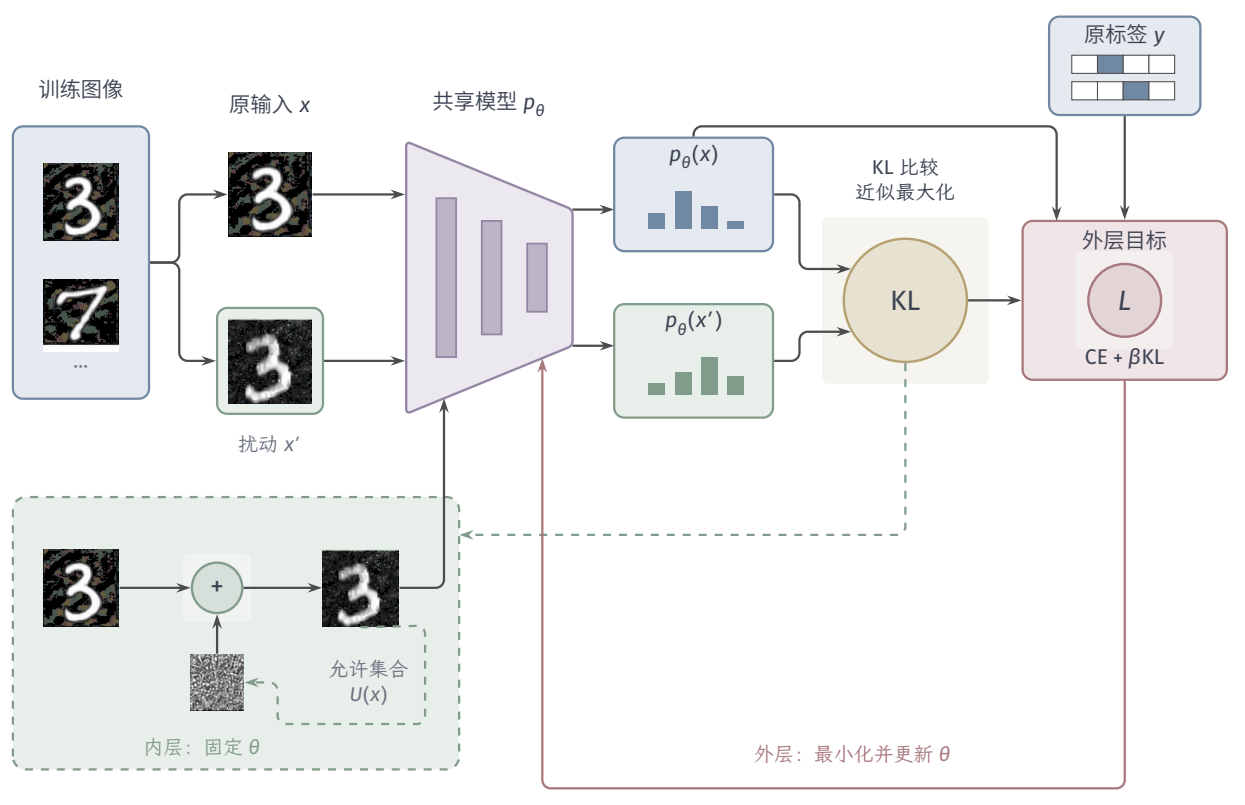

训练图像
...
原输入 x
扰动 x'
共享模型 p_θ
$p_\theta(x)$
$p_\theta(x')$
KL 比较
近似最大化
KL
原标签 y
外层目标
L
CE + βKL
+
允许集合
$U(x)$
内层：固定 θ
外层：最小化并更新 θ