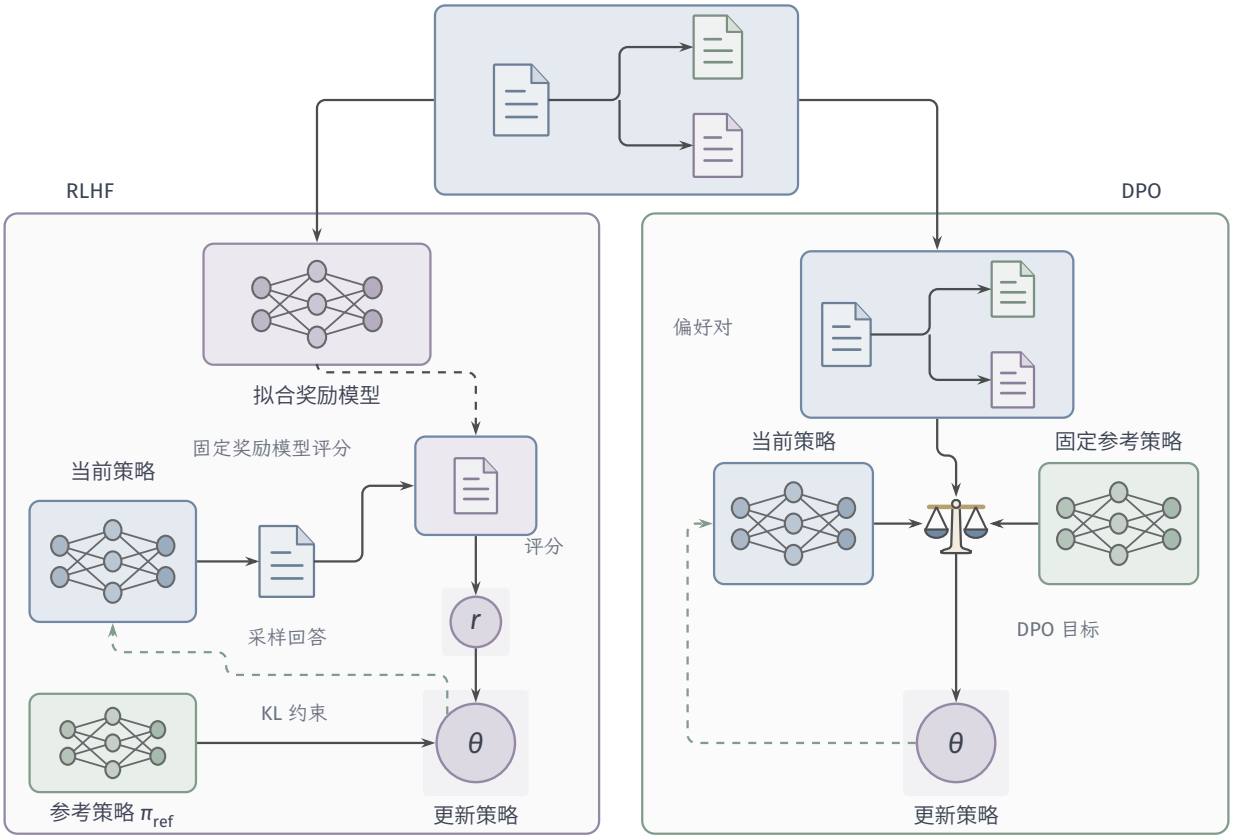

偏好对：同一提示下，更偏好与不偏好的回答
RLHF
DPO
拟合奖励模型
固定奖励模型评分
当前策略
评分
采样回答
KL 约束
参考策略 π_{ref}
更新策略
偏好对
当前策略
固定参考策略
DPO 目标
更新策略
参考策略保持固定；偏好数据的覆盖与噪声影响两条路线