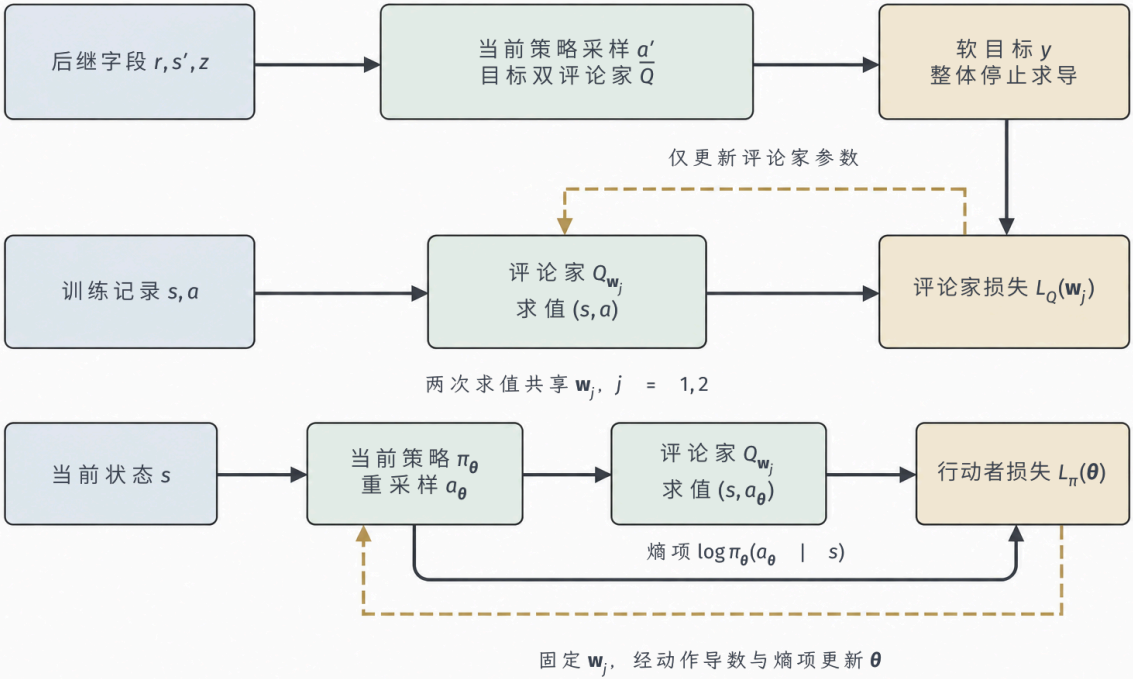

后继字段 r, s', z
当前策略采样 a'
目标双评论家 $\overline{Q}$
软目标 y
整体停止求导
仅更新评论家参数
训练记录 s, a
评论家 $Q_{\mathbf{w}_j}$
求值 (s, a)
评论家损失 $L_Q(\mathbf{w}_j)$
两次求值共享 $\mathbf{w}_j$，$j = 1, 2$
当前状态 s
当前策略 π_θ
重采样 a_θ
评论家 $Q_{\mathbf{w}_j}$
求值 (s, a_θ)
行动者损失 $L_\pi(\boldsymbol{\theta})$
熵项 $\log \pi_\theta(a_\theta \mid s)$
固定 $\mathbf{w}_j$，经动作导数与熵项更新 $\boldsymbol{\theta}$