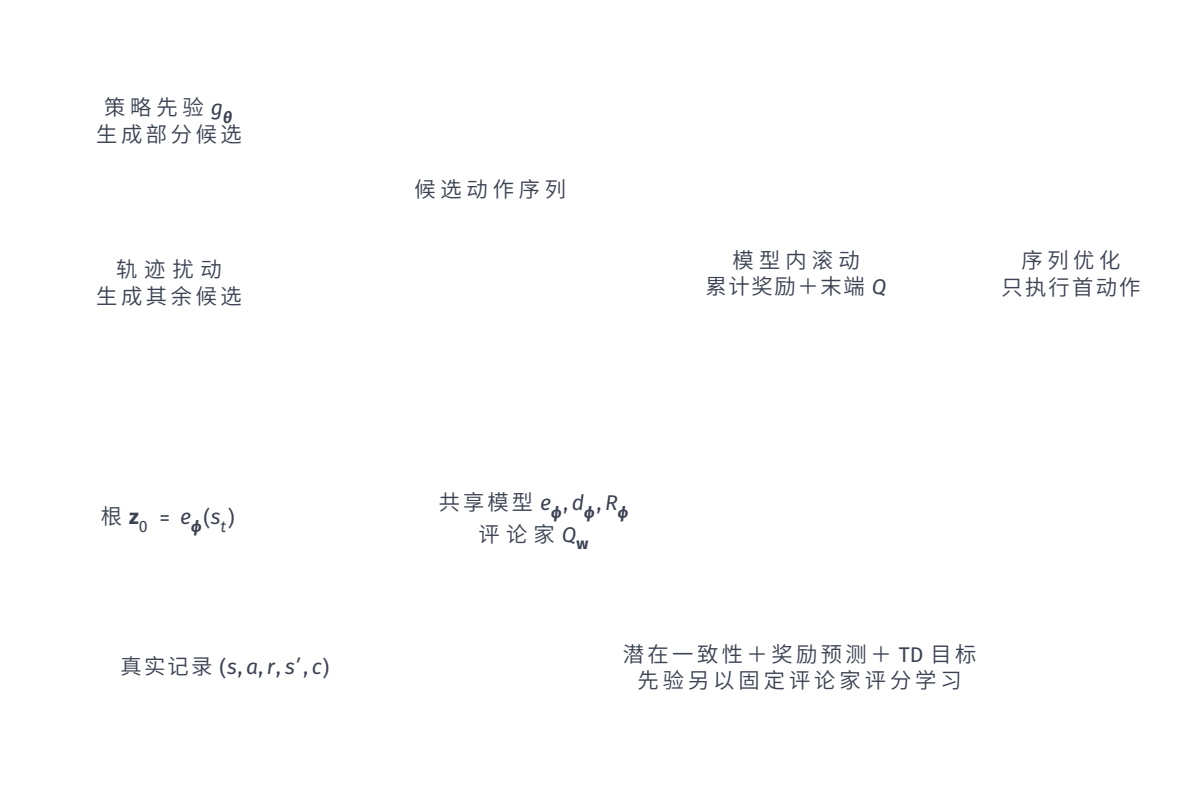
策略先验 g_θ
生成部分候选
候选动作序列
轨迹扰动
生成其余候选
模型内滚动
累计奖励＋末端 Q
序列优化
只执行首动作
根 $\mathbf{z}_0 = e_\phi(s_t)$
共享模型 e_ϕ, d_ϕ, R_ϕ
评论家 $Q_\mathbf{w}$
真实记录 (s, a, r, s', c)
潜在一致性＋奖励预测＋ TD 目标
先验另以固定评论家评分学习