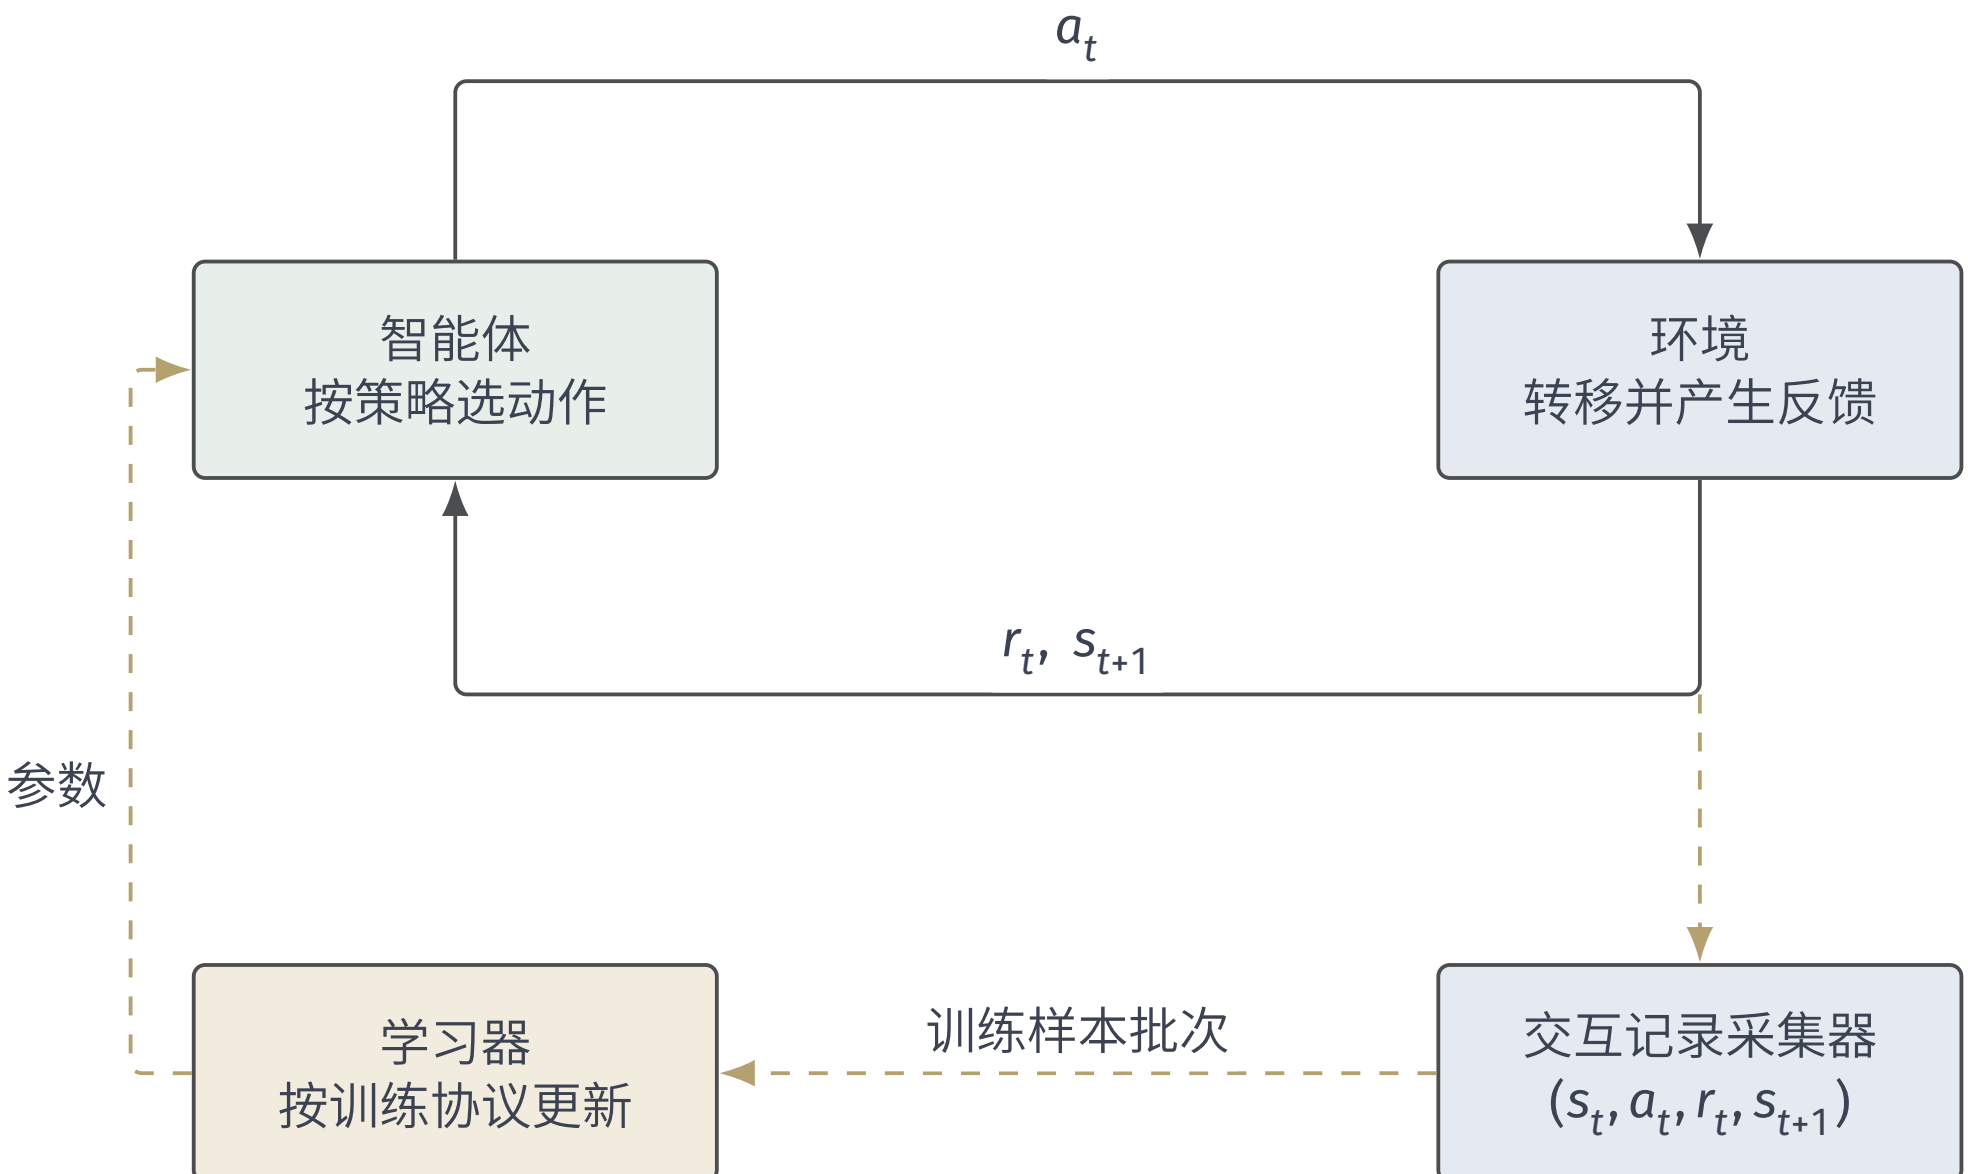

a_t
智能体
按策略选动作
环境
转移并产生反馈
$r_t,\ s_{t+1}$
参数
学习器
按训练协议更新
训练样本批次
交互记录采集器
(s_t, a_t, r_t, s_{t+1})