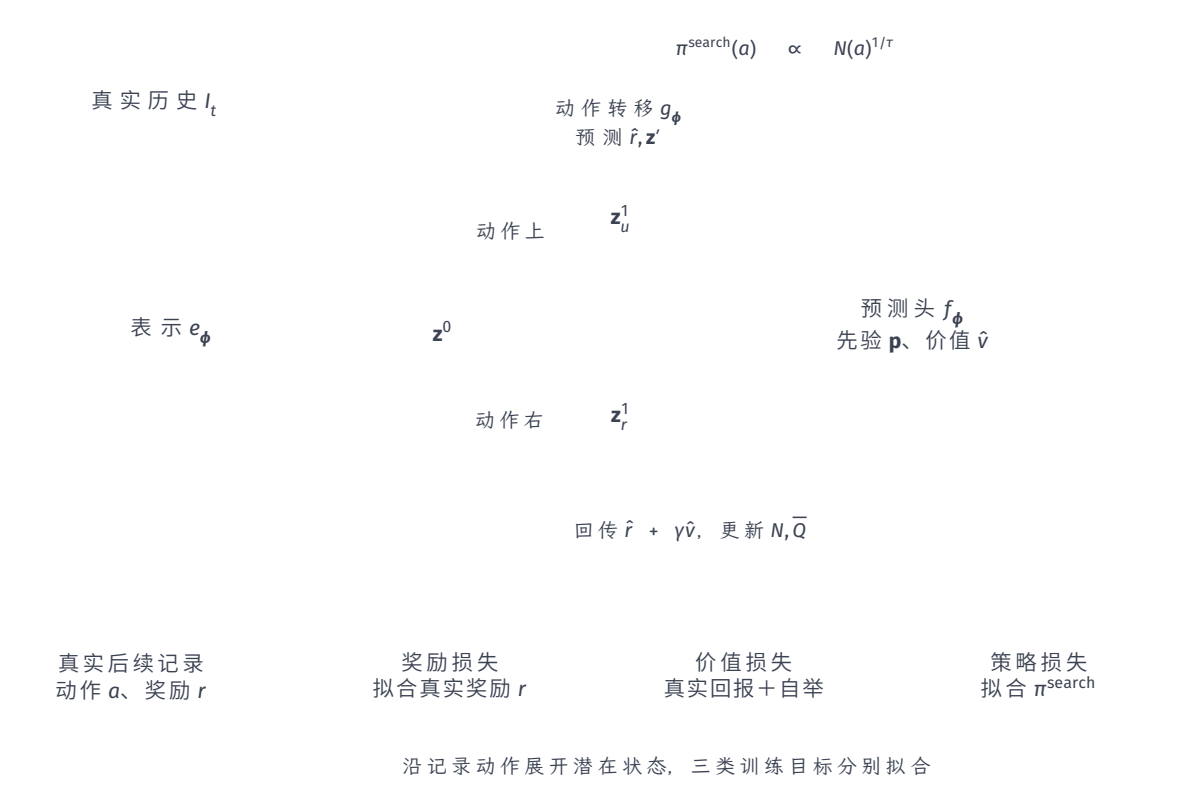
$\pi^{\text{search}}(a) \quad \propto \quad N(a)^{1/\tau}$
真实历史 I_t
动作转移 g_{ϕ}
预测 $\hat{r}, \mathbf{z}'$
动作上
$\mathbf{z}_u^1$
表示 e_{ϕ}
$\mathbf{z}^0$
预测头 f_{ϕ}
先验 $\mathbf{p}$、价值 $\hat{v}$
动作右
$\mathbf{z}_r^1$
回传 $\hat{r} + \gamma\hat{v}$，更新 $N, \overline{Q}$
真实后续记录
动作 a、奖励 r
奖励损失
拟合真实奖励 r
价值损失
真实回报＋自举
策略损失
拟合 π^{search}
沿记录动作展开潜在状态，三类训练目标分别拟合