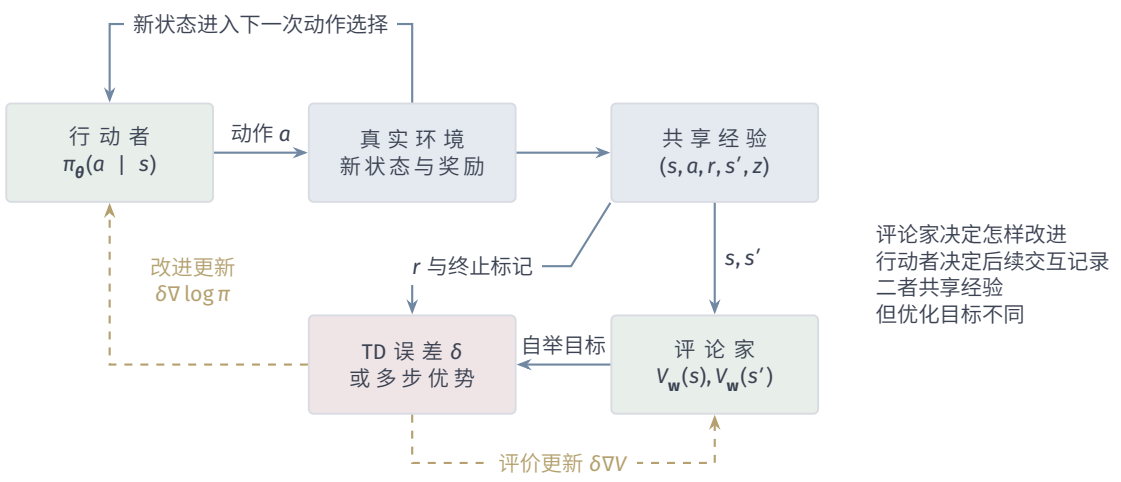

新状态进入下一次动作选择
行 动 者
$\pi_\theta(a \mid s)$
动作 a
真 实 环 境
新 状 态 与 奖 励
共 享 经 验
(s, a, r, s', z)
评论家决定怎样改进
行动者决定后续交互记录
二者共享经验
但优化目标不同
改进更新
$\delta \nabla \log \pi$
r 与终止标记
s, s'
TD 误 差 δ
或 多 步 优 势
自举目标
评 论 家
$V_{\mathbf{w}}(s), V_{\mathbf{w}}(s')$
评价更新 $\delta \nabla V$