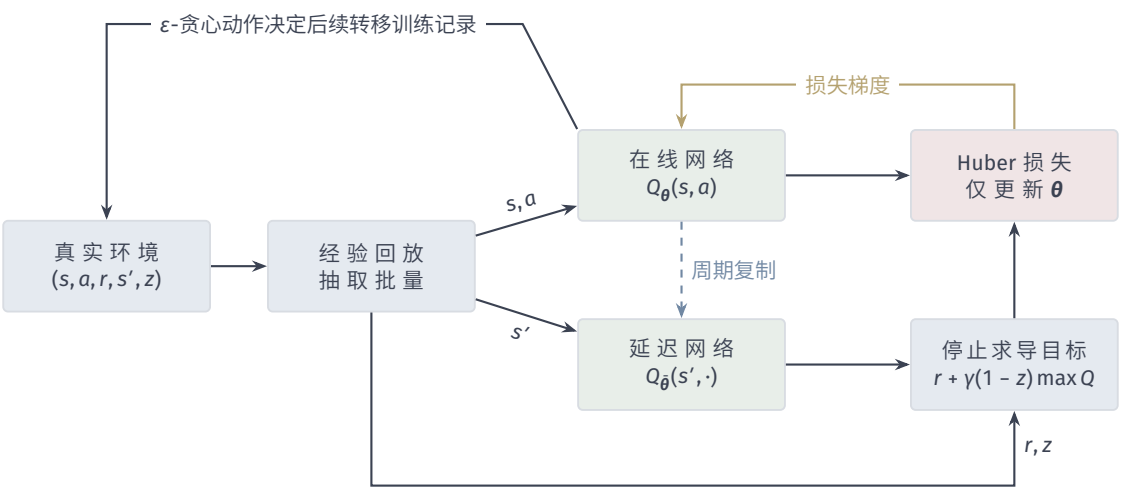

ε-贪心动作决定后续转移训练记录
损失梯度
在线网络
$Q_\theta(s,a)$
Huber 损失
仅更新 θ
真实环境
(s,a,r,s',z)
经验回放
抽取批量
s, a
周期复制
s′
延迟网络
$Q_{\hat{\theta}}(s',\cdot)$
停止求导目标
$r+\gamma(1-z)\max Q$
r, z