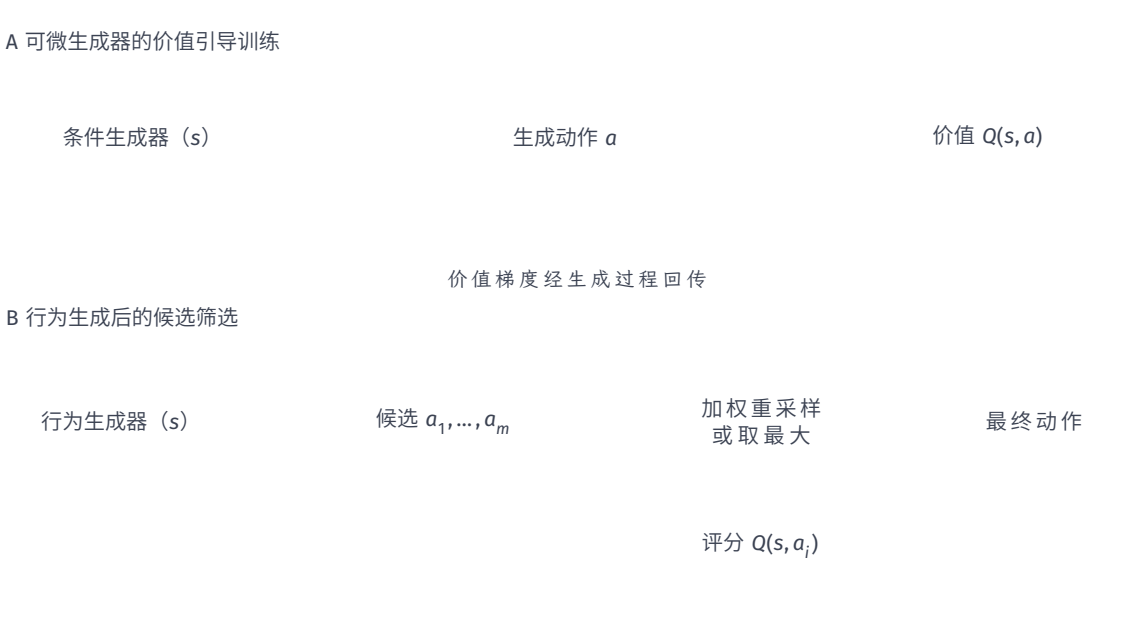

A 可微生成器的价值引导训练
条件生成器（s）
生成动作 a
价值 Q(s, a)
价值梯度经生成过程回传
B 行为生成后的候选筛选
行为生成器（s）
候选 a1, …, am
加权重采样
或取最大
最终动作
评分 Q(s, ai)