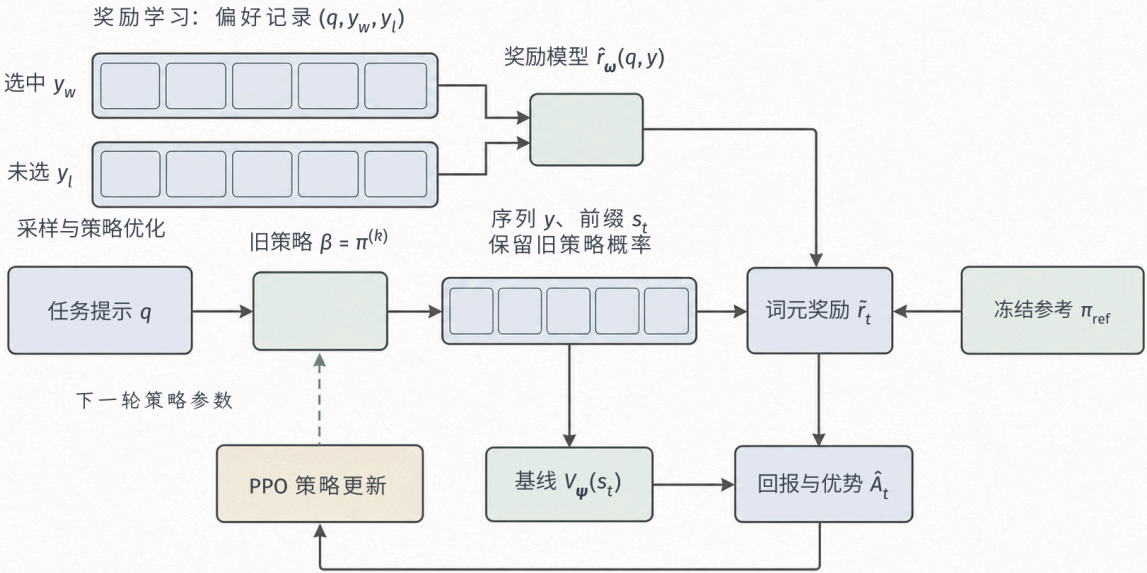

奖励学习：偏好记录 (q, y_w, y_l)
选中 y_w
未选 y_l
奖励模型 $\hat{r}_\omega(q,y)$
采样与策略优化
旧策略 $\beta = \pi^{(k)}$
序列 y、前缀 s_t
保留旧策略概率
任务提示 q
词元奖励 $\tilde{r}_t$
冻结参考 π_{ref}
下一轮策略参数
PPO 策略更新
基线 $V_\psi(s_t)$
回报与优势 $\hat{A}_t$
由序列分数与 KL 偏移构成奖励；无离散采样反传