奖励学习：偏好记录 (q, y_w, y_l)

奖励模型 $\hat{r}_{\omega}(q, y)$

选中 y_w

未选 y_l

采样与策略优化

旧策略 $\beta = \pi^{(k)}$

序列 y、前缀 s_t

保留旧策略概率

任务提示 q

词元奖励 $\tilde{r}_t$

冻结参考 π_{ref}

下一轮策略参数

PPO 策略更新

基线 $V_{\psi}(s_t)$

回报与优势 $\hat{A}_t$

由序列分数与 KL 偏移构成奖励；无离散采样反传