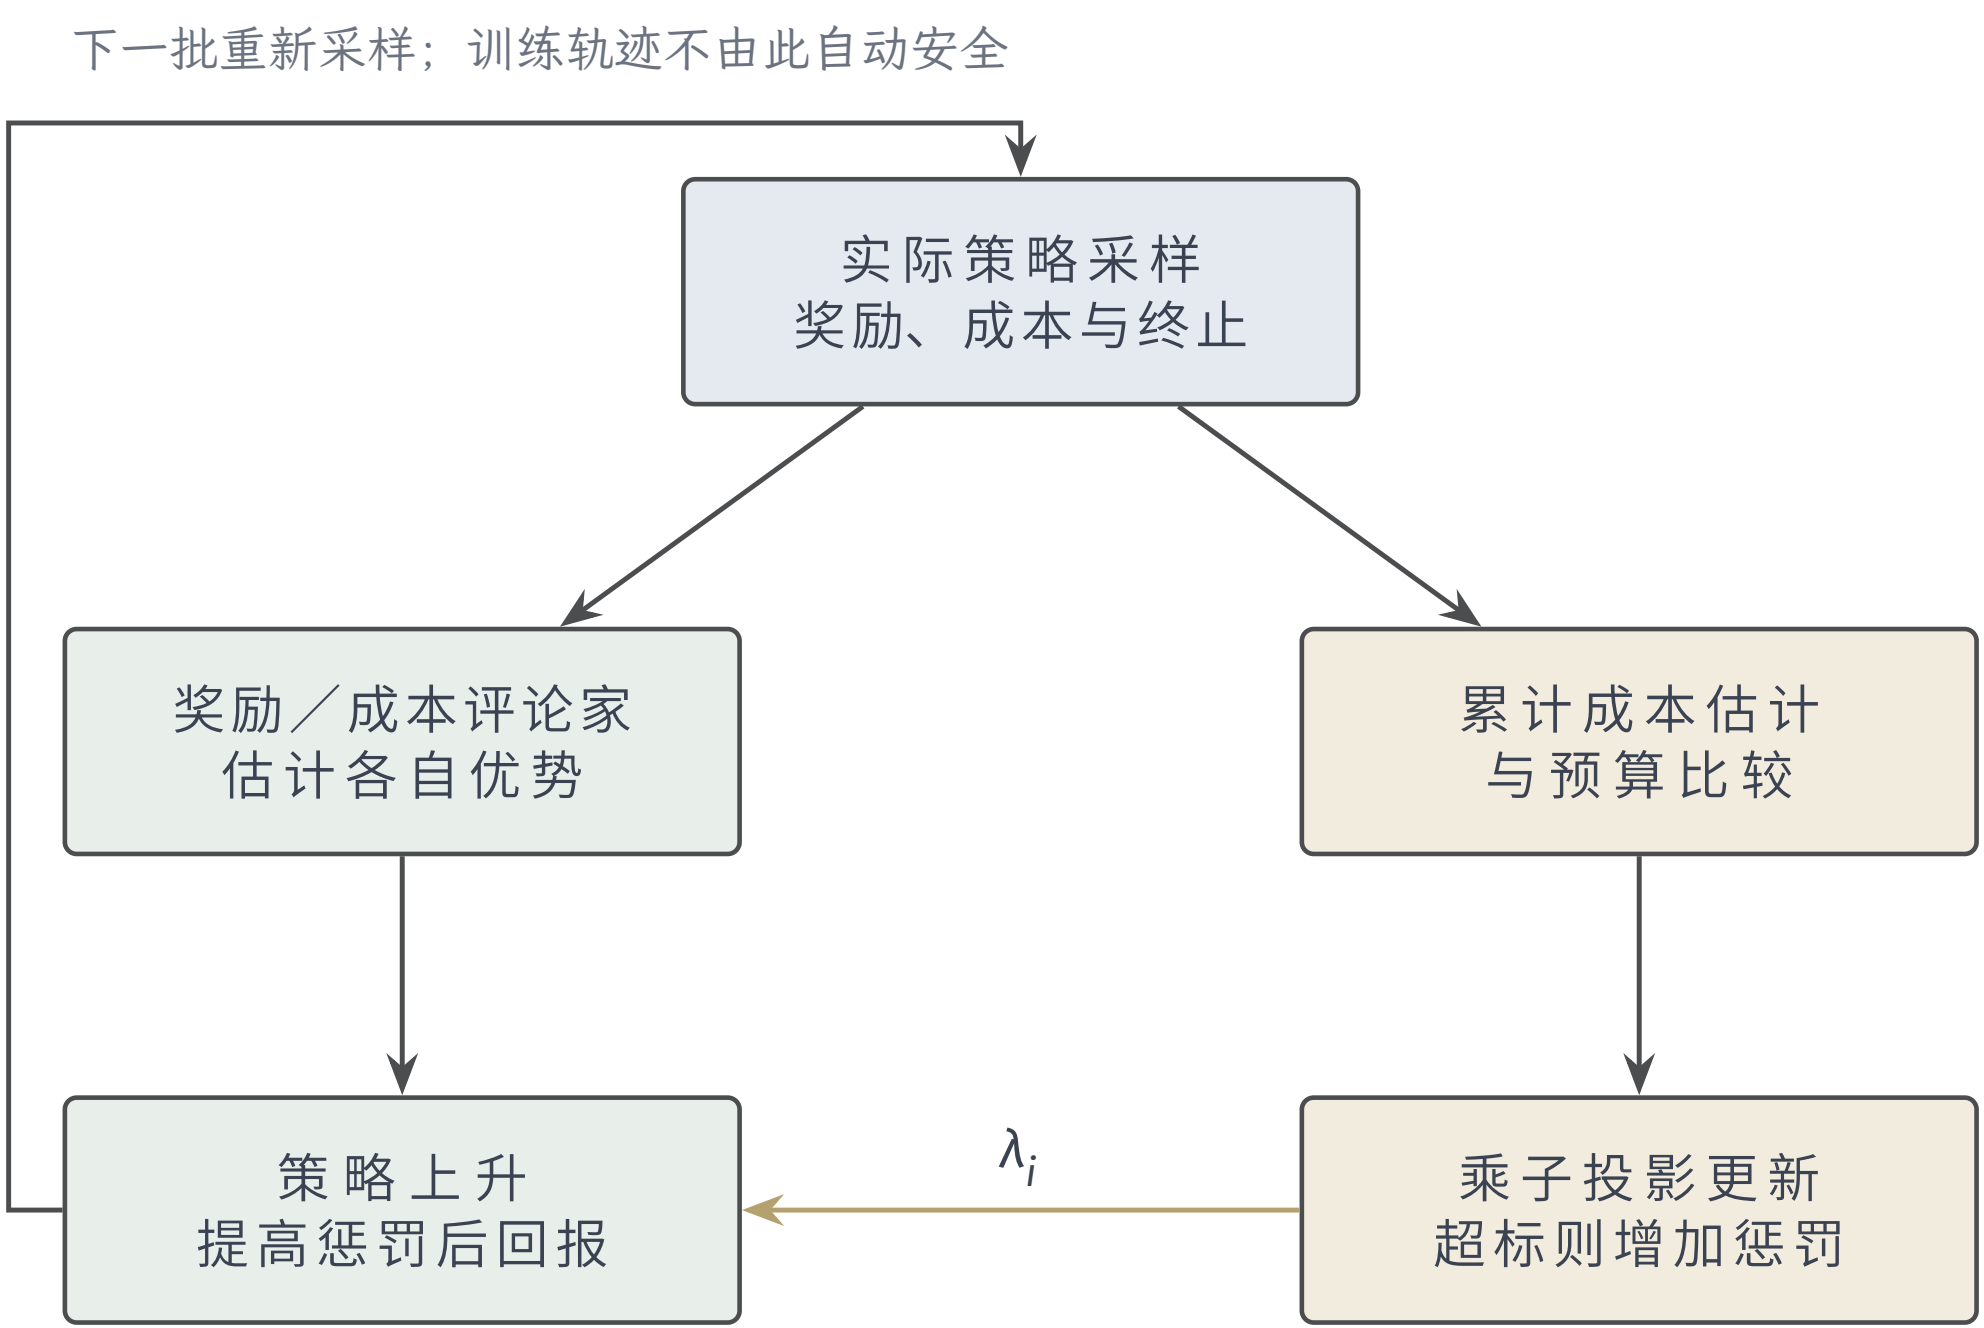

下一批重新采样；训练轨迹不由此自动安全
实际策略采样
奖励、成本与终止
奖励／成本评论家
估计各自优势
累计成本估计
与预算比较
策略上升
提高惩罚后回报
λ_i
乘子投影更新
超标则增加惩罚