# 001　引言

fig:spam-training-loss | 当前与提交前不同

提交前 · fbb26aec

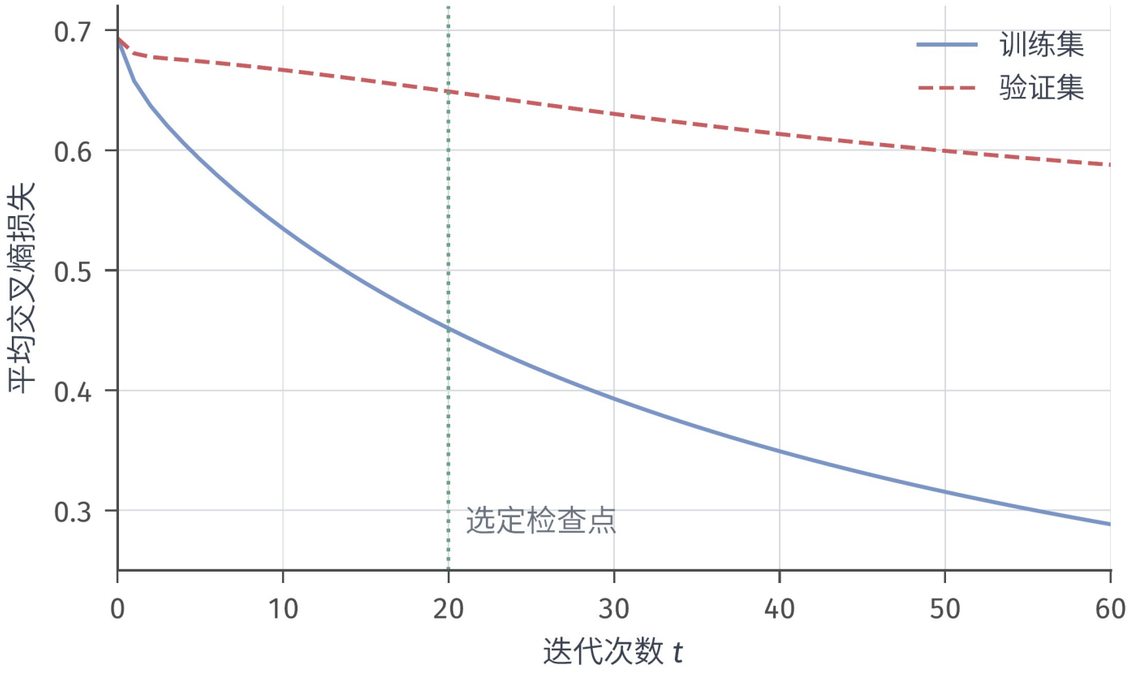


当前 · 7dd5e395

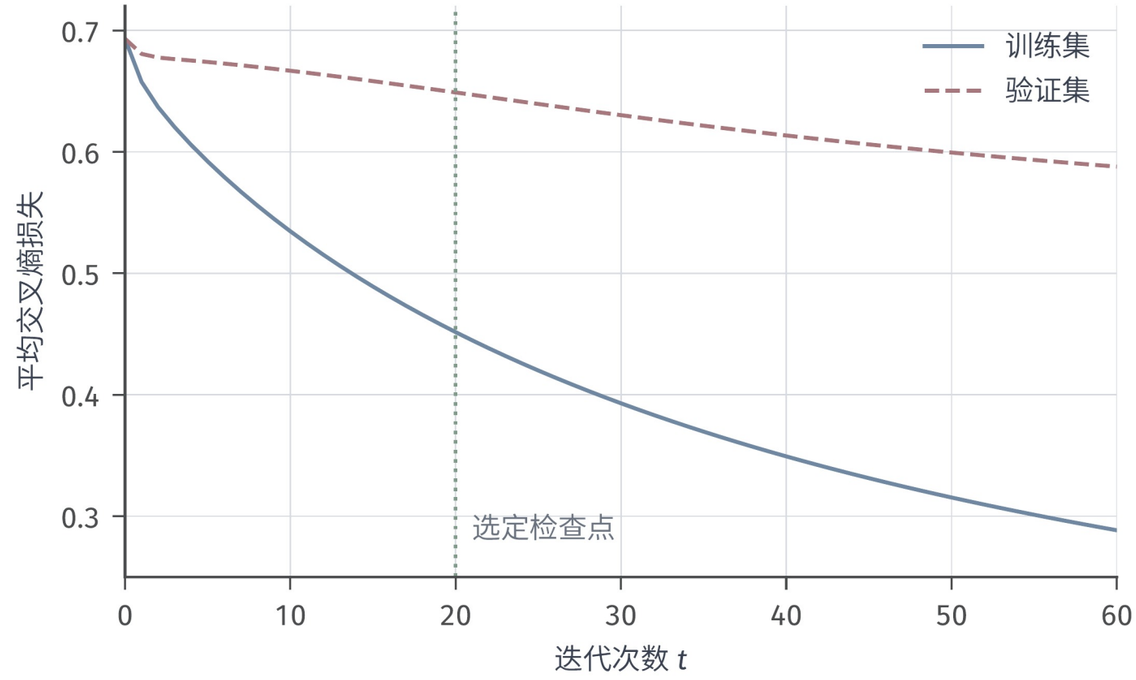


当前图注：训练集和验证集上的平均交叉熵损失。蓝色实线表示训练曲线，红色虚线表示验证曲线， 绿色竖线标出按验证准确率选定的第20次迭代；模型选择并非直接读取训练损失的最低点。

# 002 引言

fig:data-split-uses | 当前与提交前不同

## 提交前 · fbb26aec

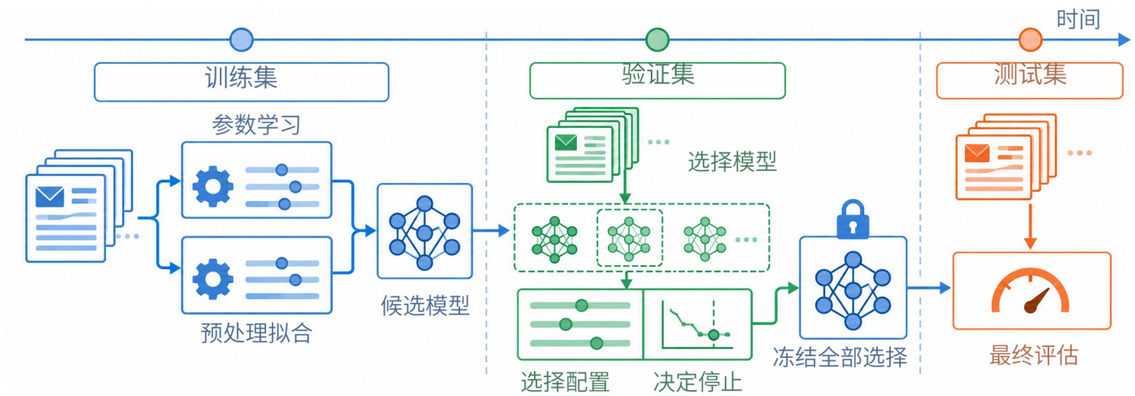


## 当前 · 7dd5e395

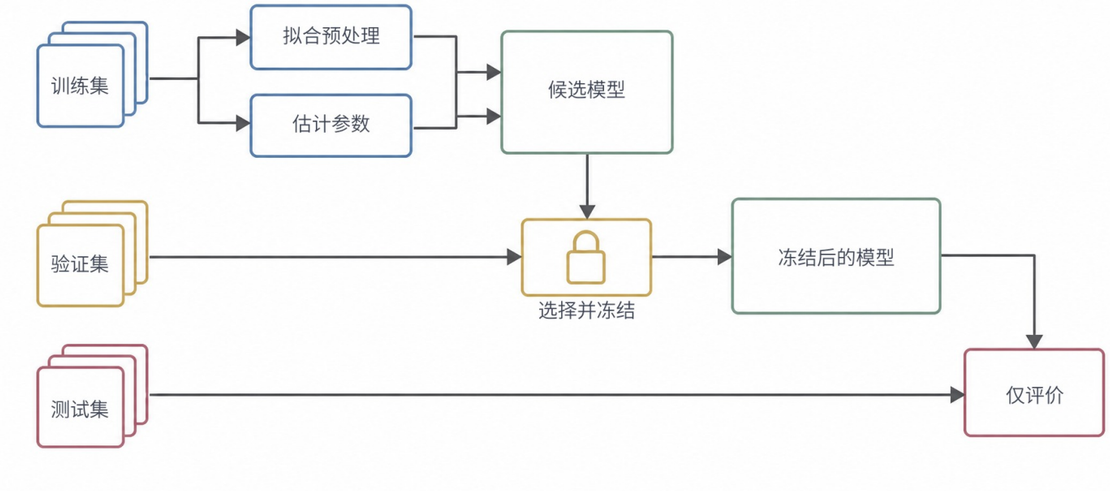


当前图注：训练集、验证集和测试集的用途。箭头表示各数据集参与拟合、选择与评价的路径；记录数量仅作示意，不代表划分比例。训练集用于参数学习与预处理拟合，验证集用于配置和停止位置的选择，测试集在这些选择冻结后才用于最终评估。

图片保持原比例；同框适配，仅用于比较独立图。完整图注与源路径见网页及清单。

# 003 模型简介

fig:models-neighbors-prototypes | 当前与提交前不同

提交前 · fbb26aec

当前 · 7dd5e395

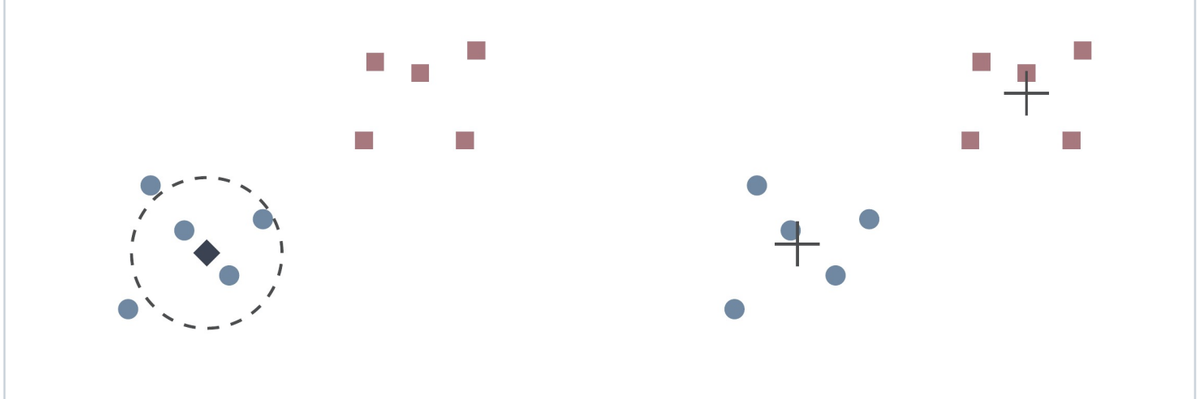


当前图注：两个k控制不同的对象。左侧kNN保存十个带标签样本，菱形表示新输入， 虚线圈内的三个近邻参加投票；右侧K-means用两个中心表示群组。 固定近邻数不会固定实例总数，固定簇数则固定了中心数量。图为表示方式的教学示意。

# 004 模型简介

fig:models-point-distribution | 当前与提交前不同

提交前 · fbb26aec

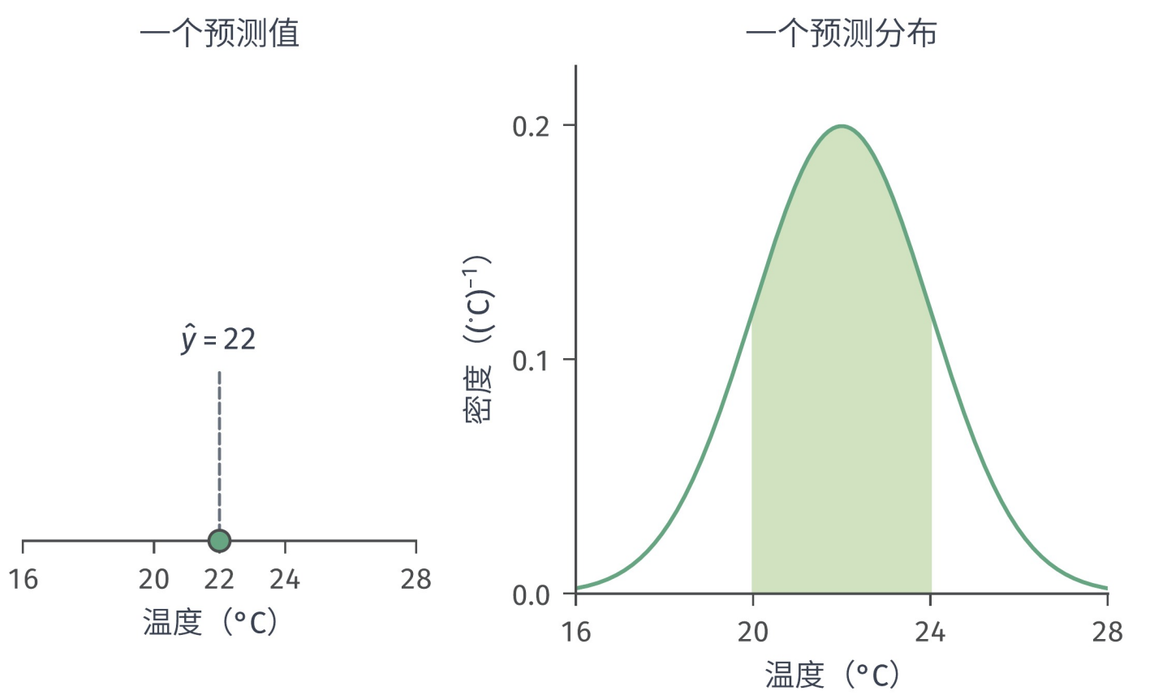


当前 · 7dd5e395

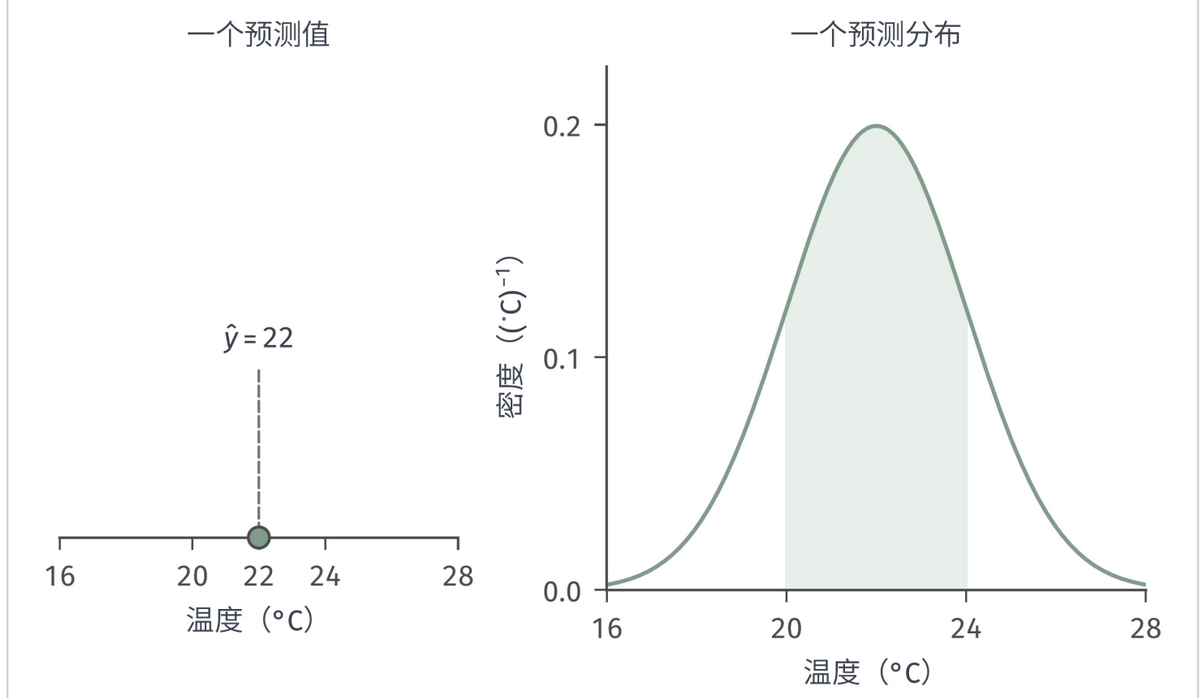


当前图注：同一温度预测的两种描述。左侧只给出一个预测值；右侧给出高斯预测分布， 阴影面积表示温度落在20到24\,^C之间的概率。数值用于教学示意。

# 005 模型简介

fig:models-discriminative-generative | 当前与提交前不同

提交前 · fbb26aec

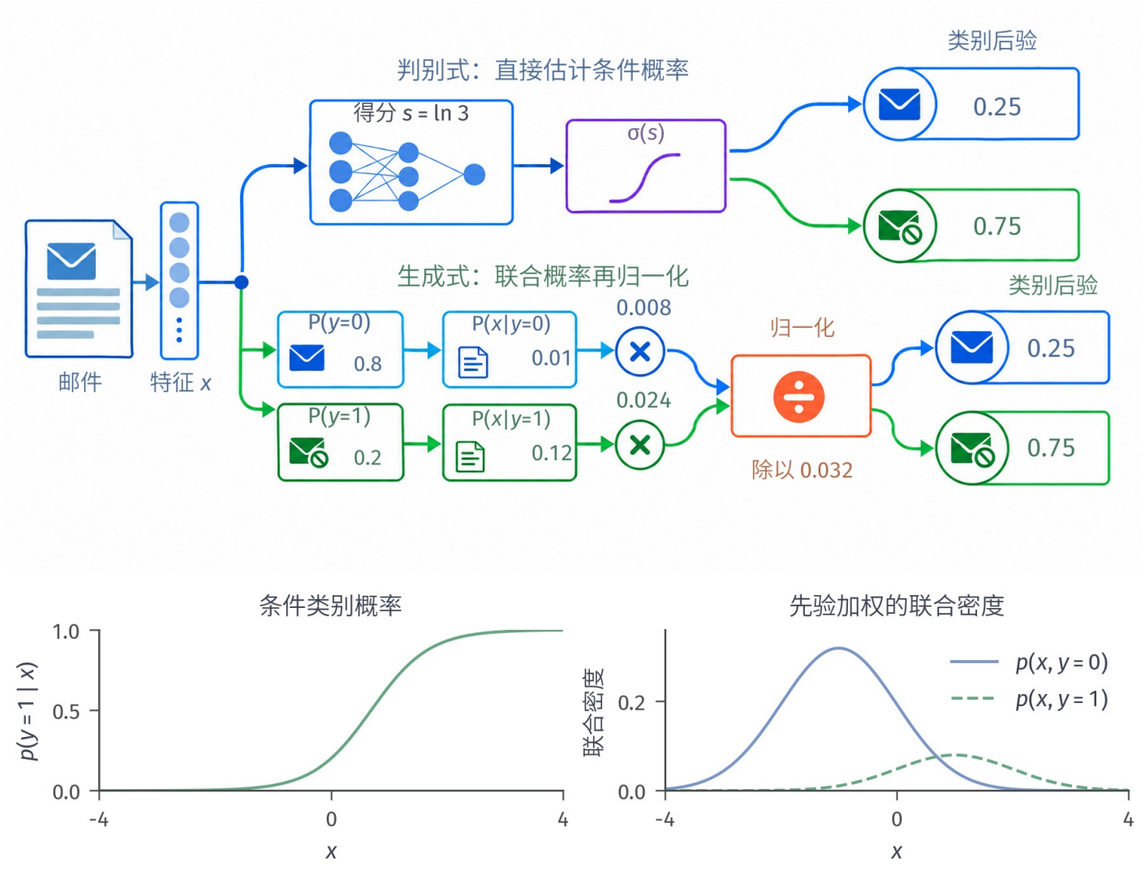


当前 · 7dd5e395

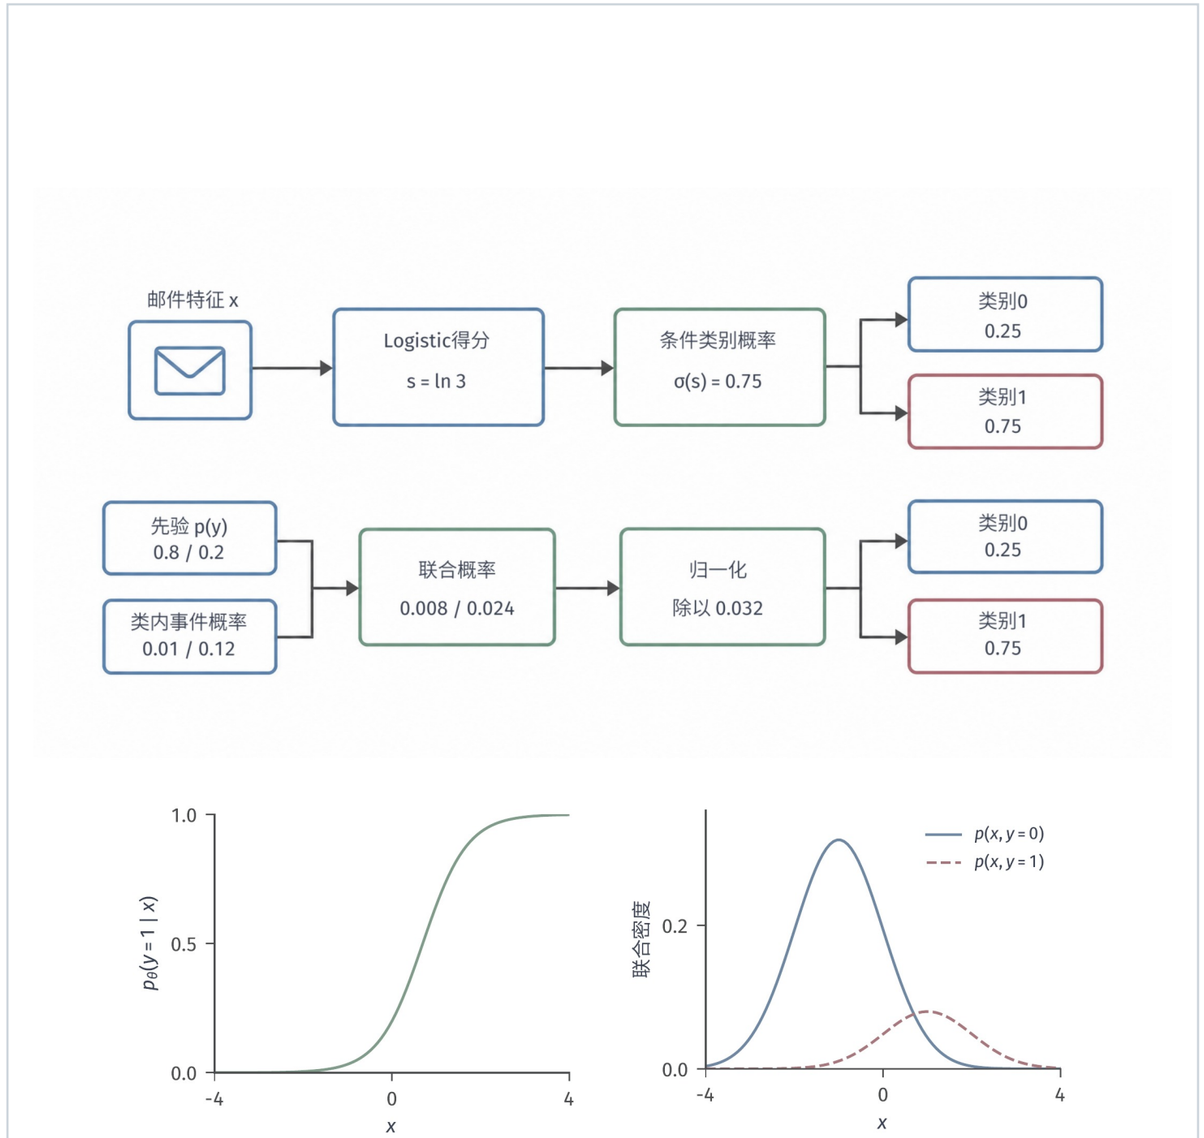


当前图注：两条分类建模路线。上部框图中的判别式路线以二分类Logistic读出为例，令得分s=3，则(s)=0.75，得到类别后验p(y=1 x)=0.75、p(y=0 x)=0.25。生成式路线沿用离散邮件教学数值，先验0.8、0.2与类内事件概率0.01、0.12相乘，分别得到联合概率0.008、0.024，再除以总和0.032。两条路线的数值仅作可核算示意，不假定实际训练结果相同。

# 006 模型简介

fig:models-linear-nonlinear | 当前与提交前不同

提交前 · fbb26aec

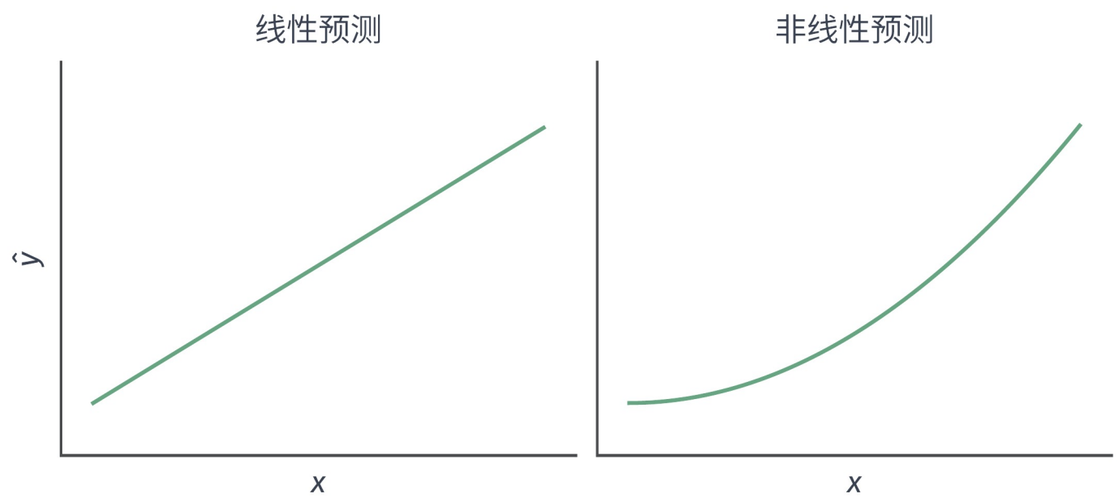


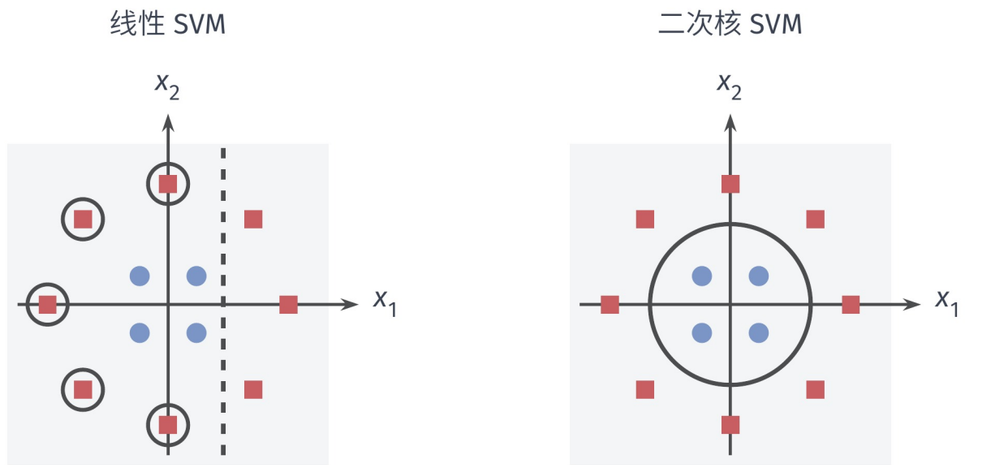


当前 · 7dd5e395

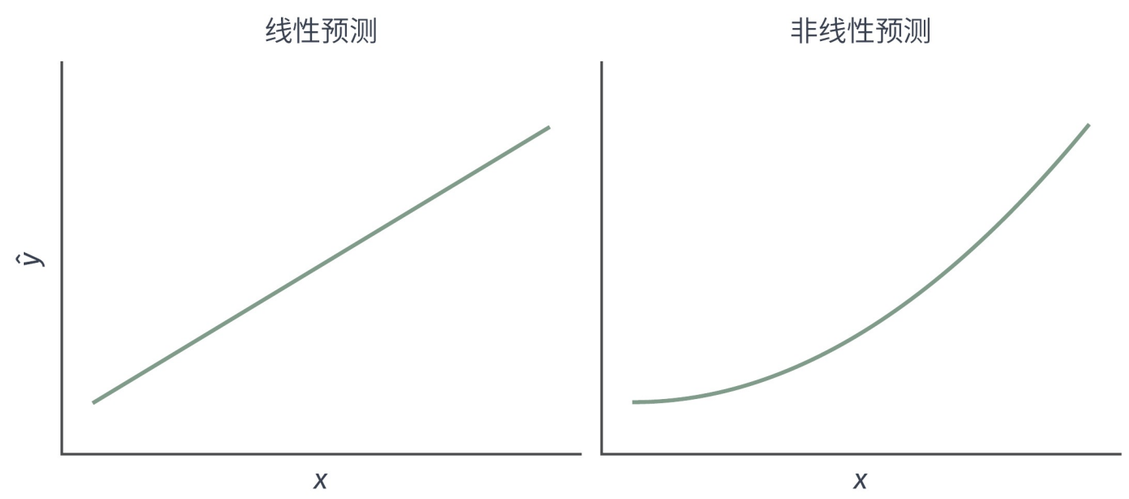


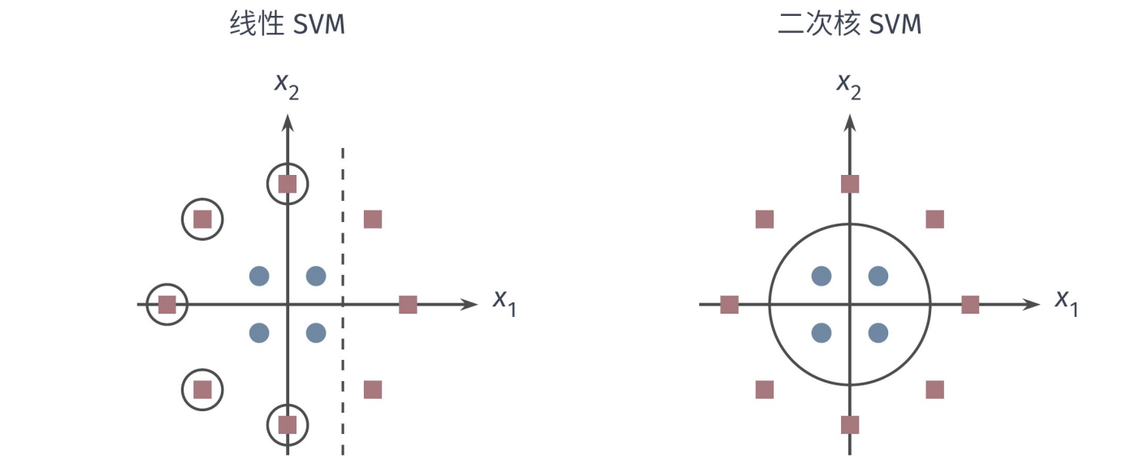


当前图注：线性与非线性关系的几何示意。上排依次为线性预测与非线性预测， 下排用同一组环形样本对照线性SVM的限制与二次核SVM的表达能力；圆点和方点代表两类。 左图虚线只展示一条候选直线，空心圈标出按其左右类别分配时的错分方点，不代表最优SVM解。 外圈方点的凸包包含内圈圆点，故任何直线都不能完全分离这组样本。 右图以圆心为坐标原点，半径8的边界可由二次核 ( u, v)=( u^ v)

图片保持原比例；同框适配，仅用于比较独立图。完整图注与源路径见网页及清单。

# 007 模型简介

fig:models-tree-partition | 当前与提交前不同

提交前 · fbb26aec

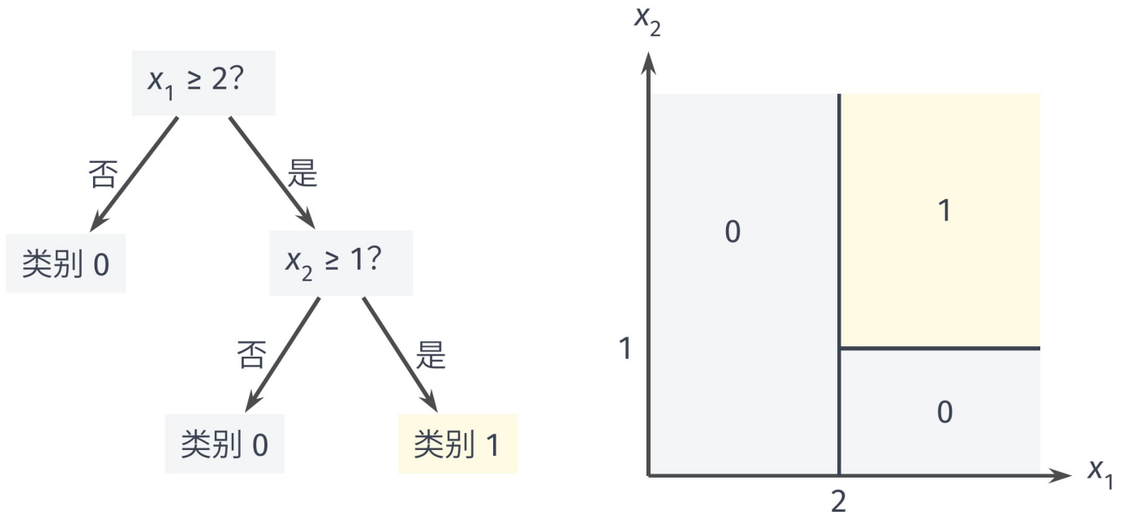


当前 · 7dd5e395

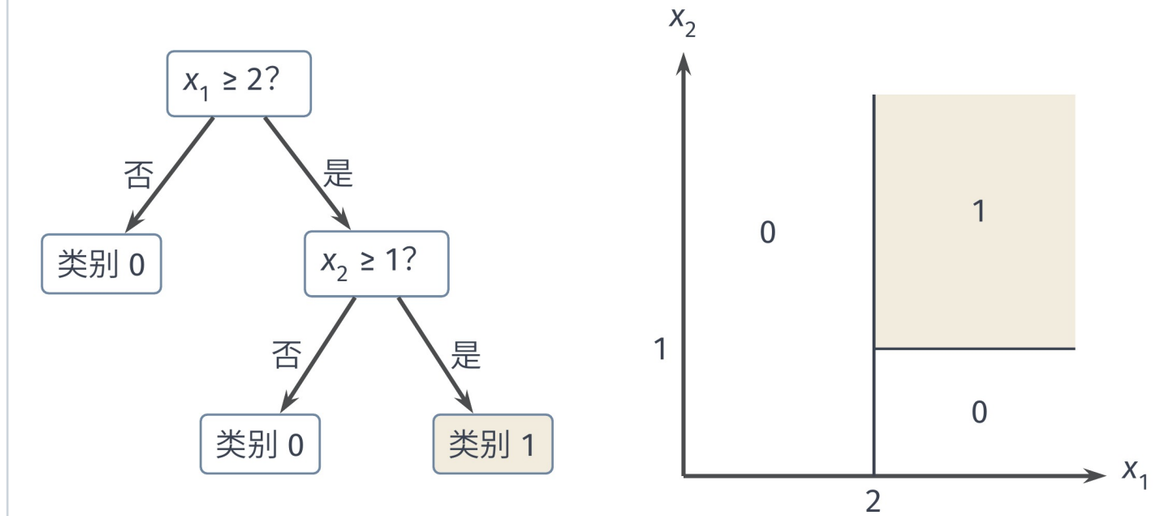


当前图注：按条件分情况处理输入。左侧为判断树，右侧为对应的输入区域。 该教学例子在x_12且x_21时输出类别1，其余区域输出0。

# 008 模型简介

fig:models-vector-comparison | 当前与提交前不同

提交前 · fbb26aec

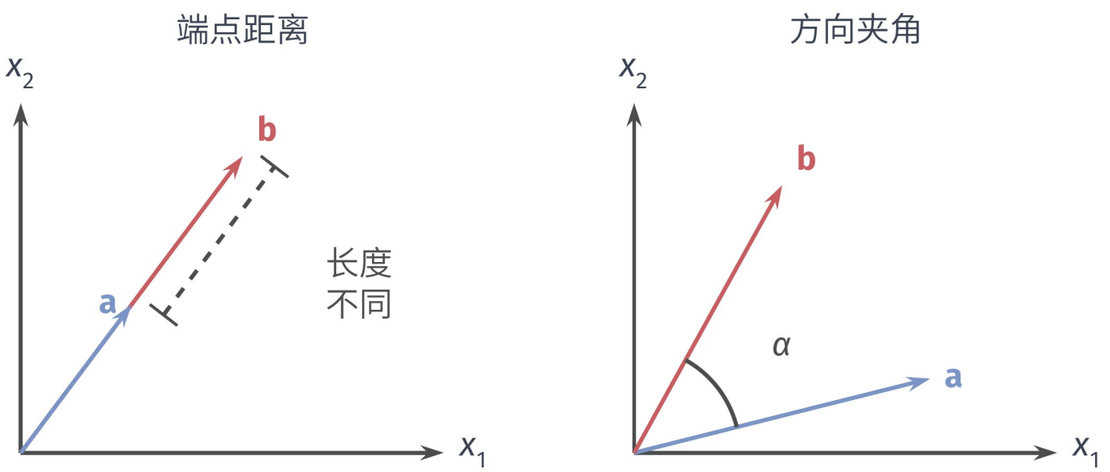


当前 · 7dd5e395

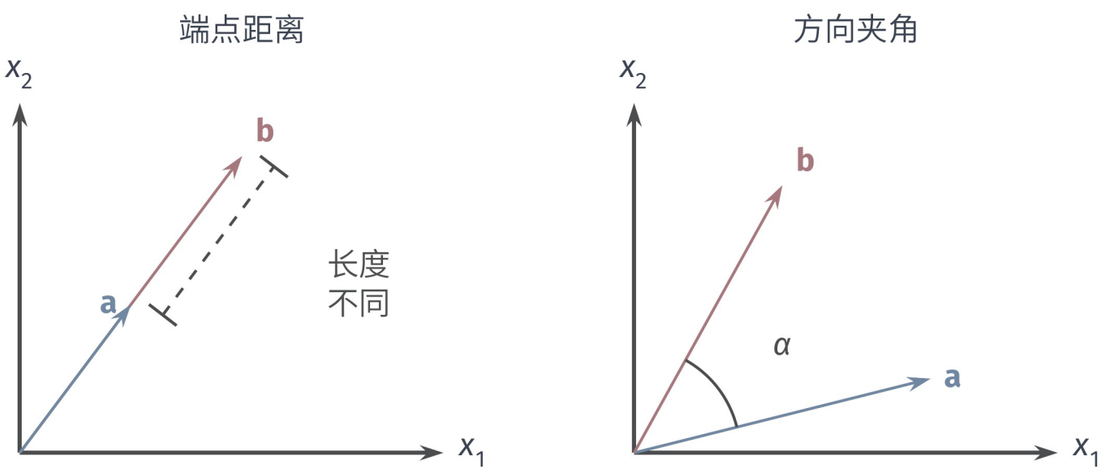


当前图注：两种向量比较方式关注不同差异。左侧比较两个端点之间的距离， 右侧比较向量方向之间的夹角。同向但长度不同的向量，余弦损失为零，欧氏误差仍大于零。

图片保持原比例；同框适配，仅用于比较独立图。完整图注与源路径见网页及清单。

# 009 模型简介

fig:models-spatial-objectives | 当前与提交前不同

## 提交前 · fbb26aec

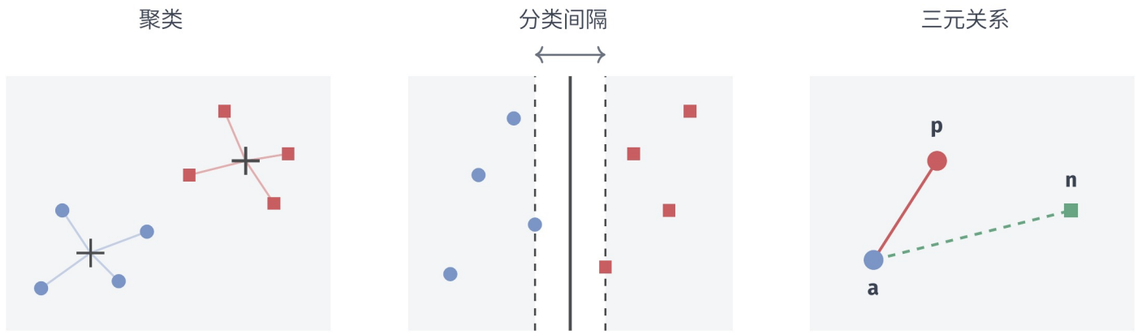


## 当前 · 7dd5e395

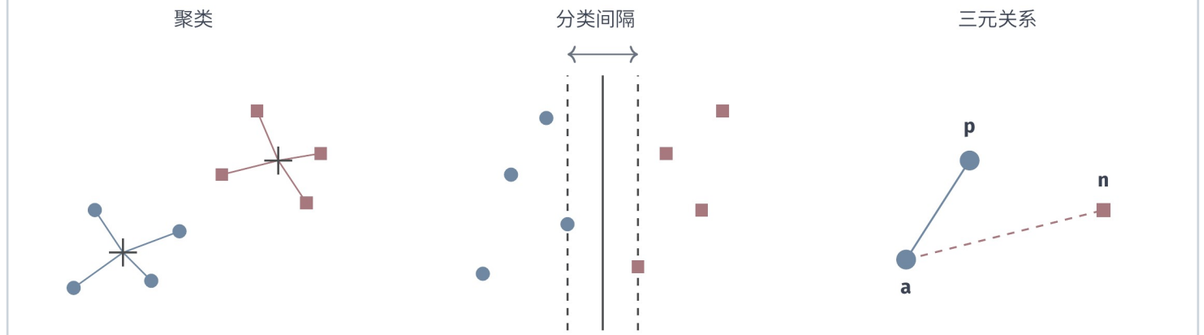


当前图注：三种几何要求。左侧缩短样本到所属中心的距离；中间让带标签样本与分类边界保持 间隔；右侧要求相关样本比不相关样本更接近参照样本。三者分别比较不同的几何对象。

图片保持原比例；同框适配，仅用于比较独立图。完整图注与源路径见网页及清单。

# 010 范式简介

fig:supervised-mnist-process | 当前与提交前不同

提交前 · fbb26aec

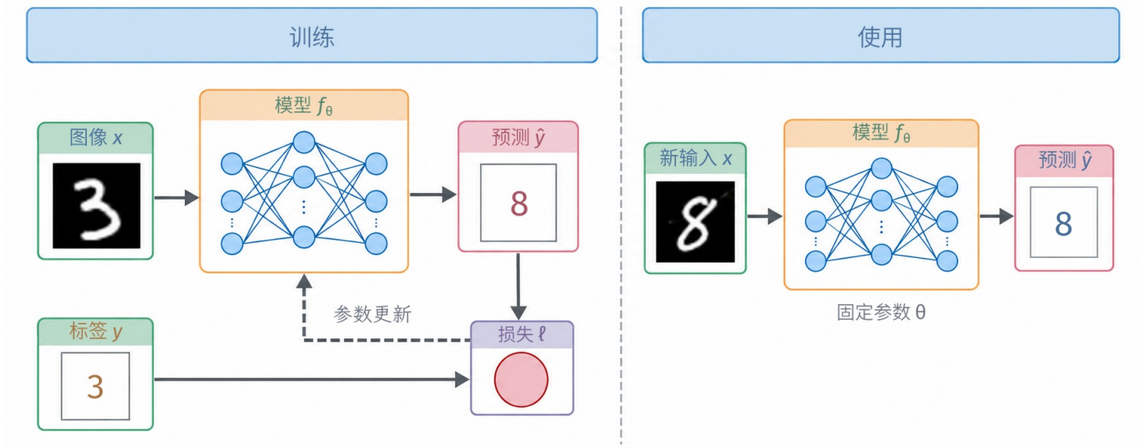


当前 · 7dd5e395

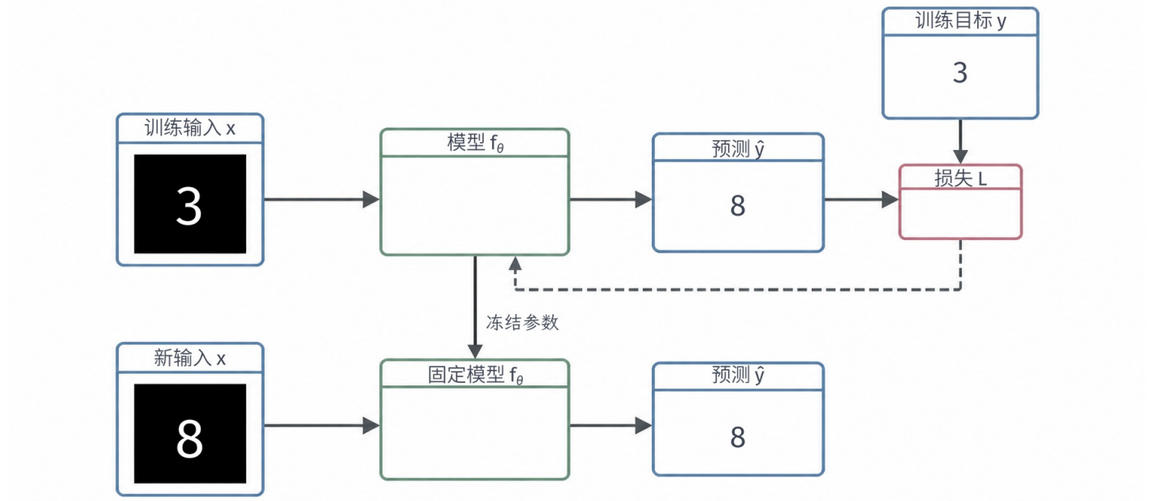


当前图注：监督学习中的训练与使用。训练时图像进入模型，目标标签单独进入损失比较，虚线反馈用于更新参数；使用时只提供新图像。训练行中，数字3被暂时预测为8，原标签3只进入比较；使用行没有提供目标。数字字形为教学构造，不是MNIST原始样本；模型框不指定网络架构。

# 011　范式简介

fig:unsupervised-topic-process | 当前与提交前不同

## 提交前 · fbb26aec

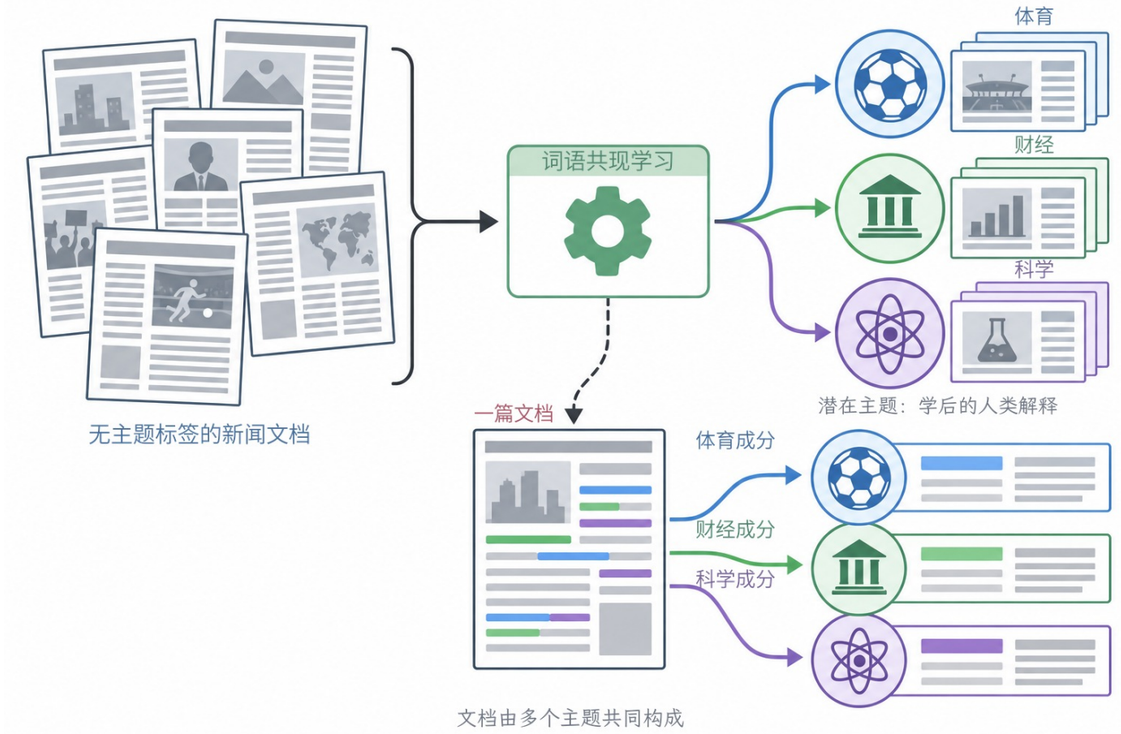


## 当前 · 7dd5e395

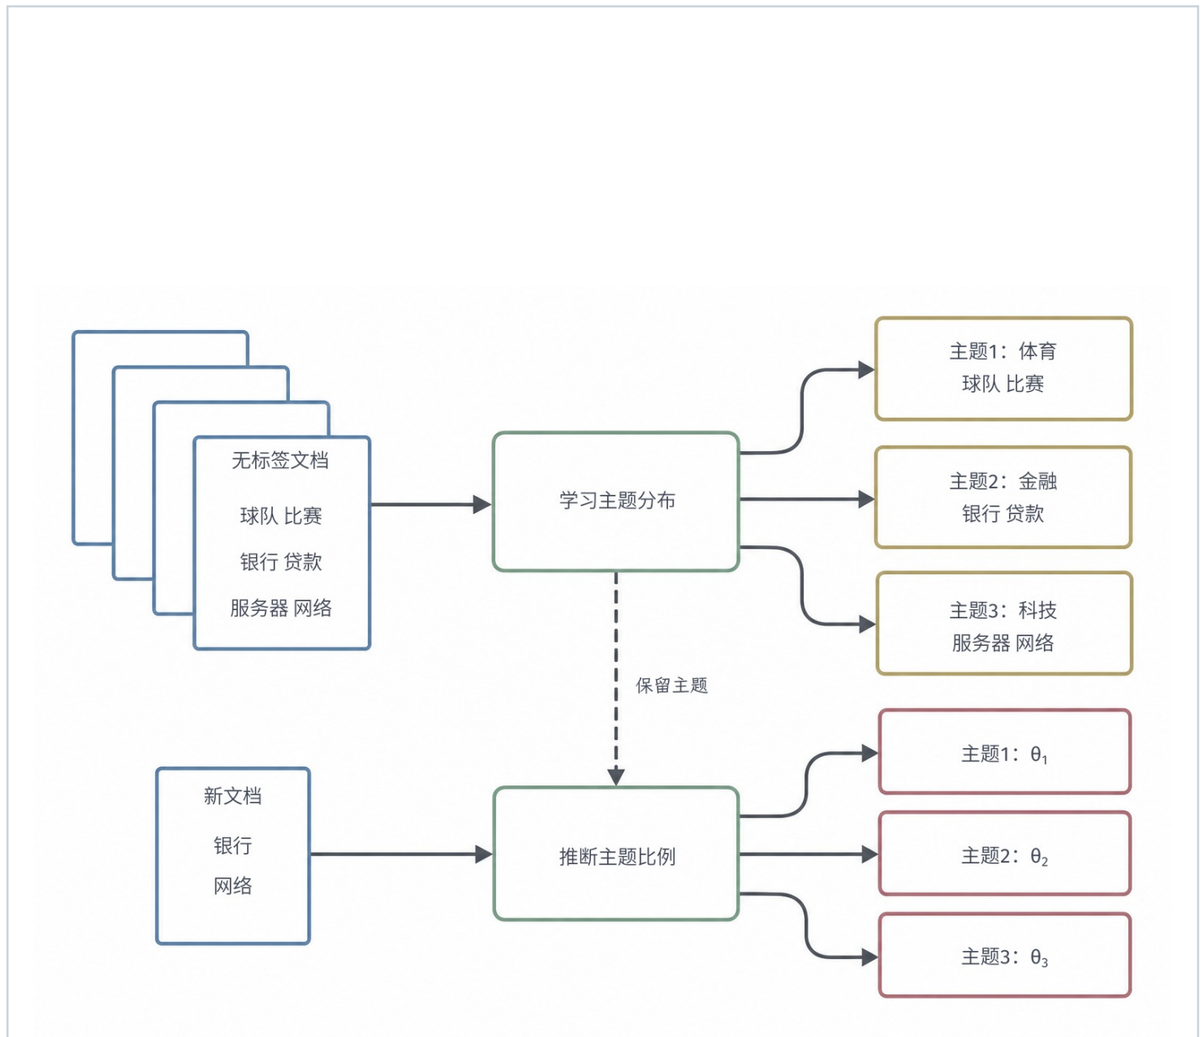


当前图注：无监督主题发现的过程示意。没有主题标签的新闻集合提供词语共现信息，学习过程形成 若干潜在主题；同一篇文档可以由多个主题共同构成，主题名称是在结果解释阶段由人给出的。

# 012 范式简介

fig:reinforcement-atari-process | 当前与提交前不同

提交前 · fbb26aec

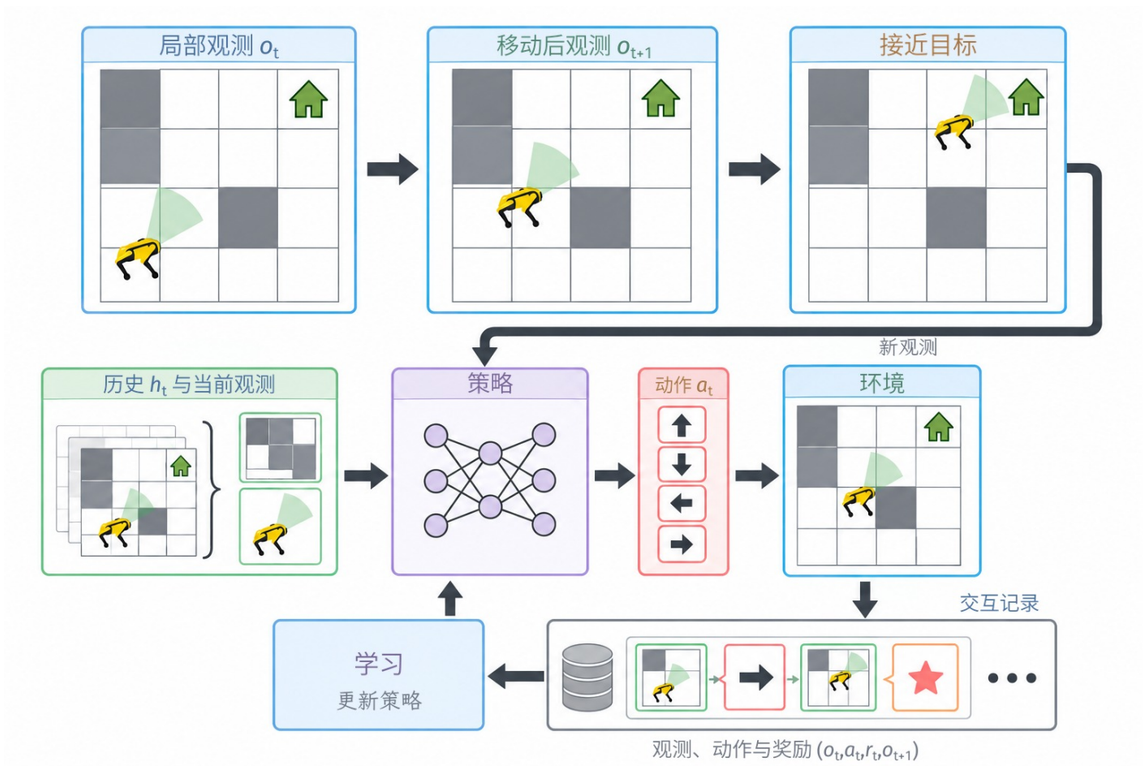


当前 · 7dd5e395

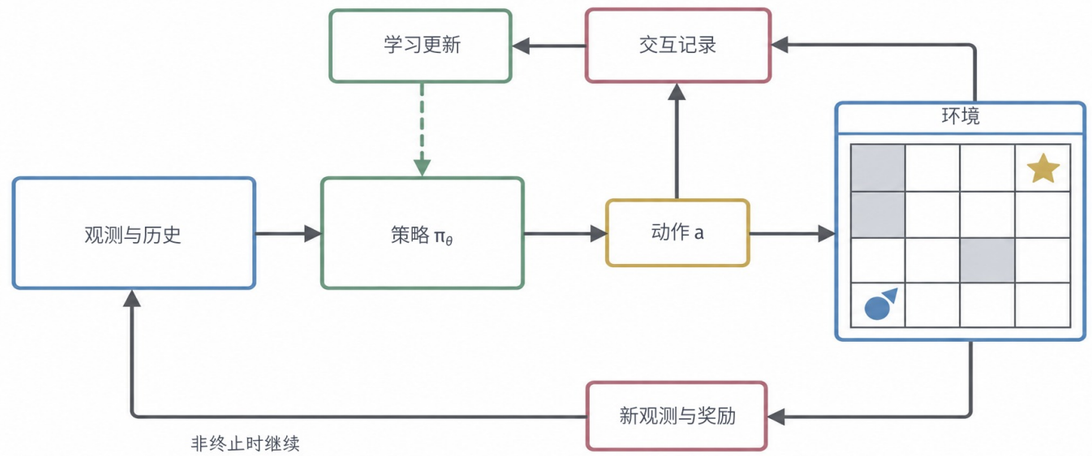


当前图注：机器人探索中的强化学习交互。策略依据观测与历史选择动作，环境返回新观测与奖励；动作和环境反馈共同形成交互记录，学习过程据此更新策略，非终止时继续交互。格图中的机器人、障碍与目标仅为概念场景，不表示测量结果、精确状态转移或回合终止。奖励不是正确动作标签。

# 013 范式简介

fig:semi-supervised-image-process | 当前与提交前不同

## 提交前 · fbb26aec

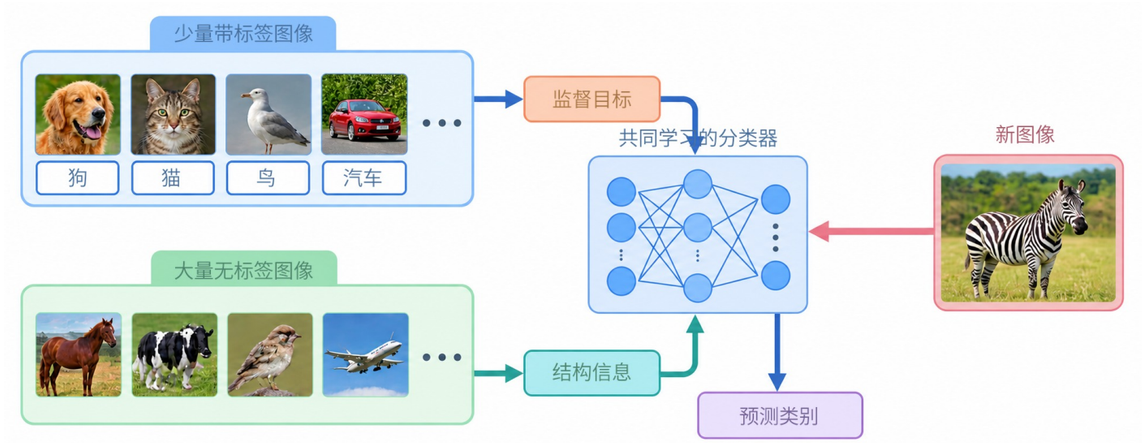


## 当前 · 7dd5e395

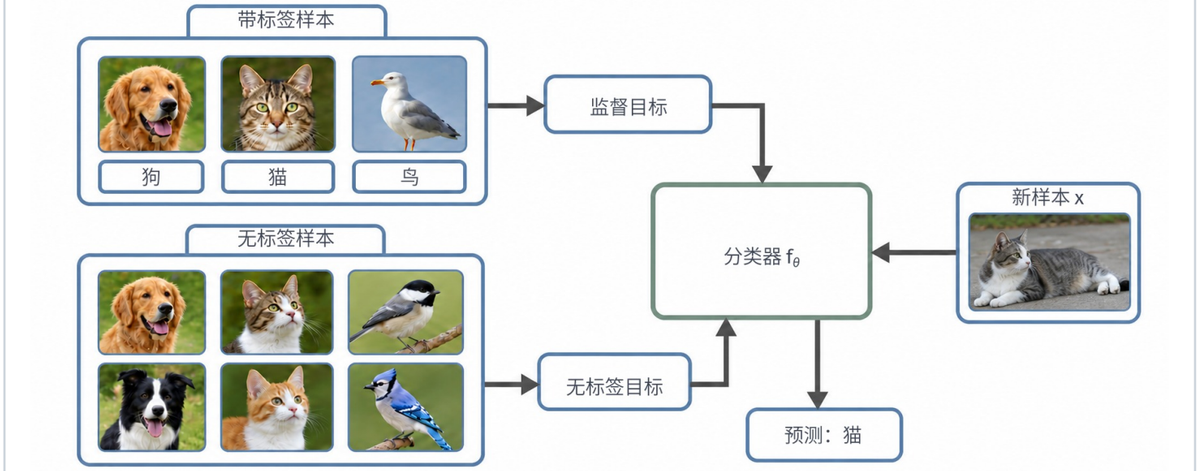


当前图注：半监督学习的过程示意。少量带类别标签的图片规定目标，大量无标签图片提供额外结构信息，两路经验共同用于形成分类能力，汇入同一分类器。模型框不指定网络结构；动物图片为教学构造。无标签图片的隐藏真值不能作为训练答案使用。

# 014 范式简介

fig:self-supervised-masked-process | 当前与提交前不同

## 提交前 · fbb26aec

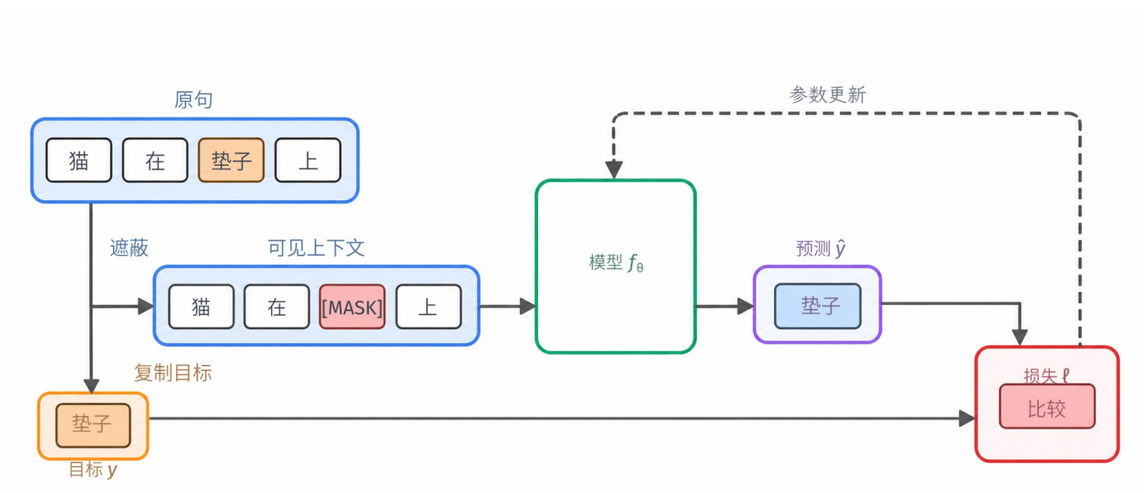


## 当前 · 7dd5e395

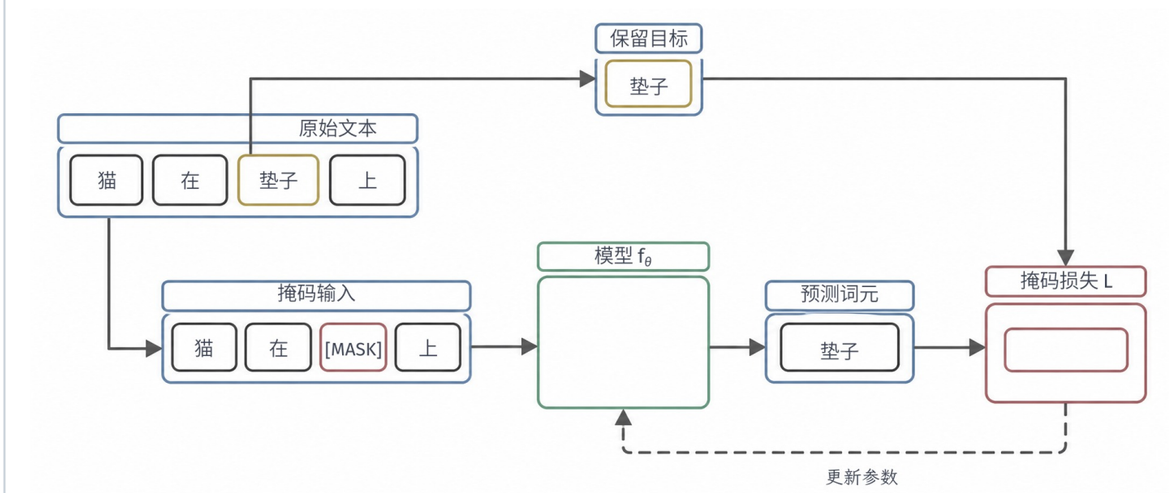


当前图注：掩码预测以“猫在垫子上”为教学例子。输入将“垫子”替换为[MASK]，原词单独保留为比较目标；模型只能读可见上下文，不能读被保留的答案。可见词元共同进入模型，灰色虚线将损失反馈到参数；模型框不指定网络结构。

# 015 范式简介

fig:weak-supervision-process | 当前与提交前不同

## 提交前 · fbb26aec

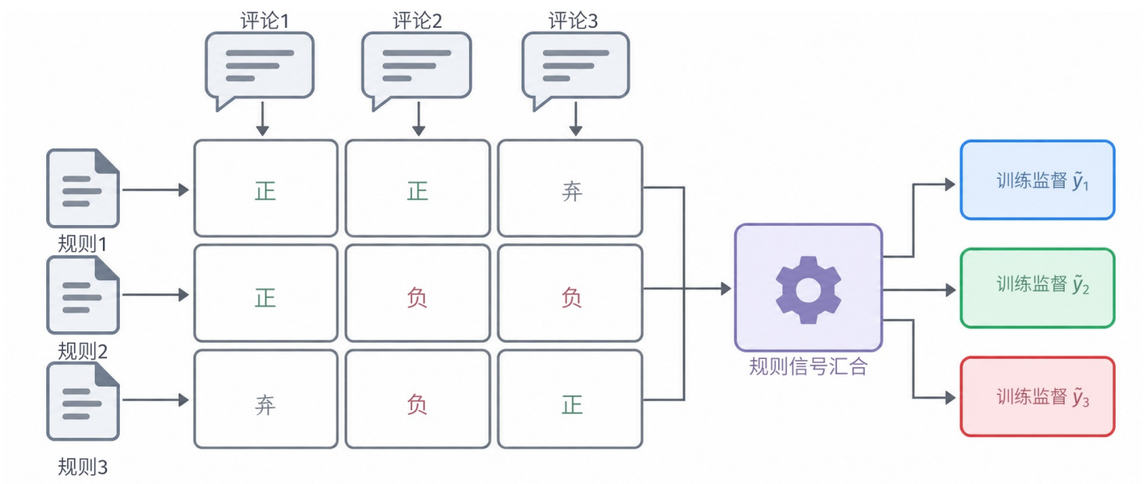


## 当前 · 7dd5e395

当前图注：三条规则在三个未标注评论上的教学投票。正、负、弃分别表示两种倾向与弃票；同一列可能存在冲突。综合规则信号形成训练监督 y_i，图中不规定合并算法，也不把某条规则输出等同于真实标签；评价仍使用独立可靠标签。

# 016 范式简介

fig:contrastive-learning-process | 当前与提交前不同

## 提交前 · fbb26aec

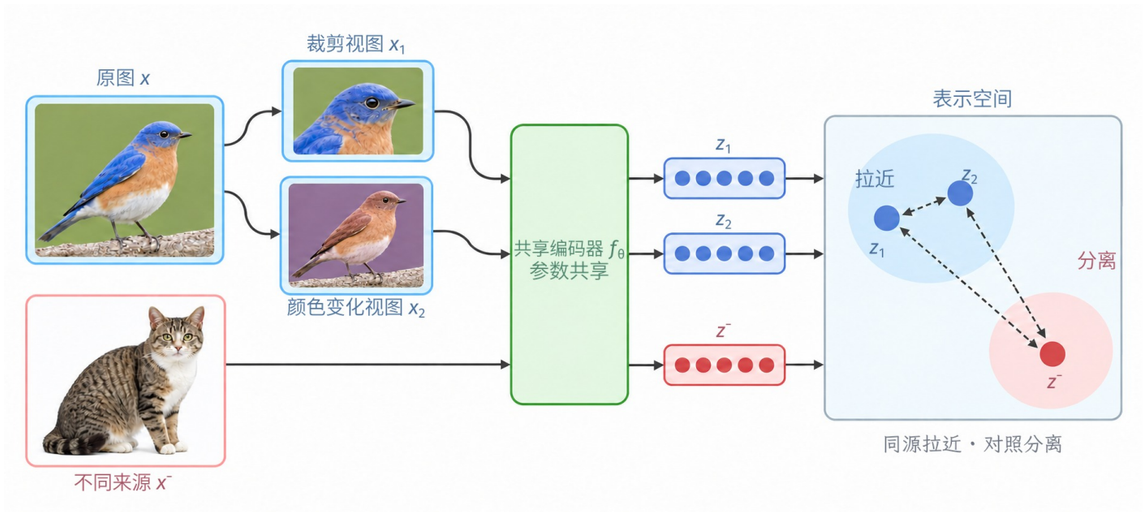


## 当前 · 7dd5e395

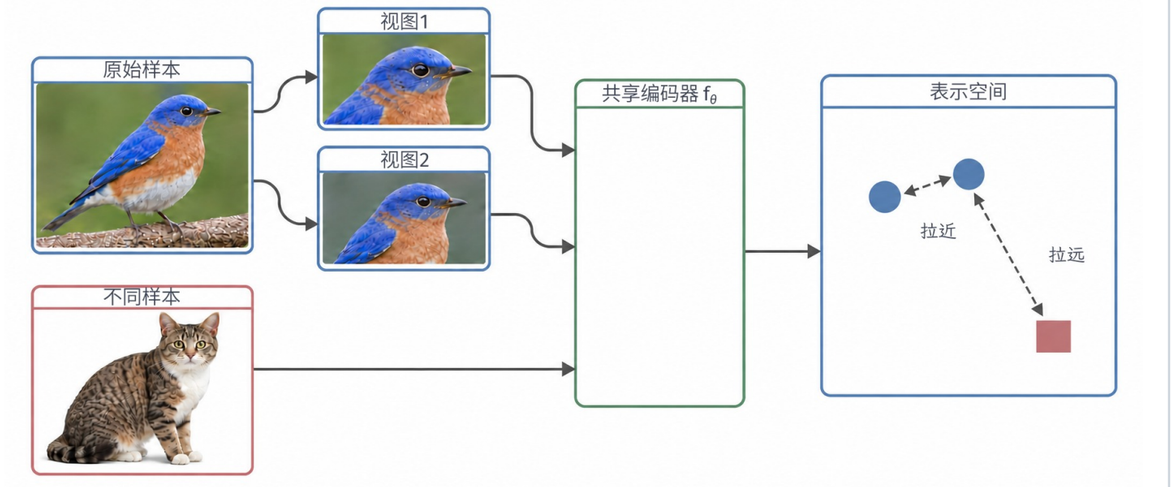


当前图注：自监督对比学习的教学示意。同一幅鸟的原图分别经裁剪与颜色变化形成两个视图；它们与另一幅猫图的视图经共享参数的编码器得到表示。两个蓝色点表示同源视图的表示，红色点表示其他原图的对照；箭头只示意同源拉近与对照相对分离的训练目标。动物图元和表示位置均为教学构造，不是实测影像或表示分布。

# 017 范式简介

fig:active-learning-loop | 当前与提交前不同

## 提交前 · fbb26aec

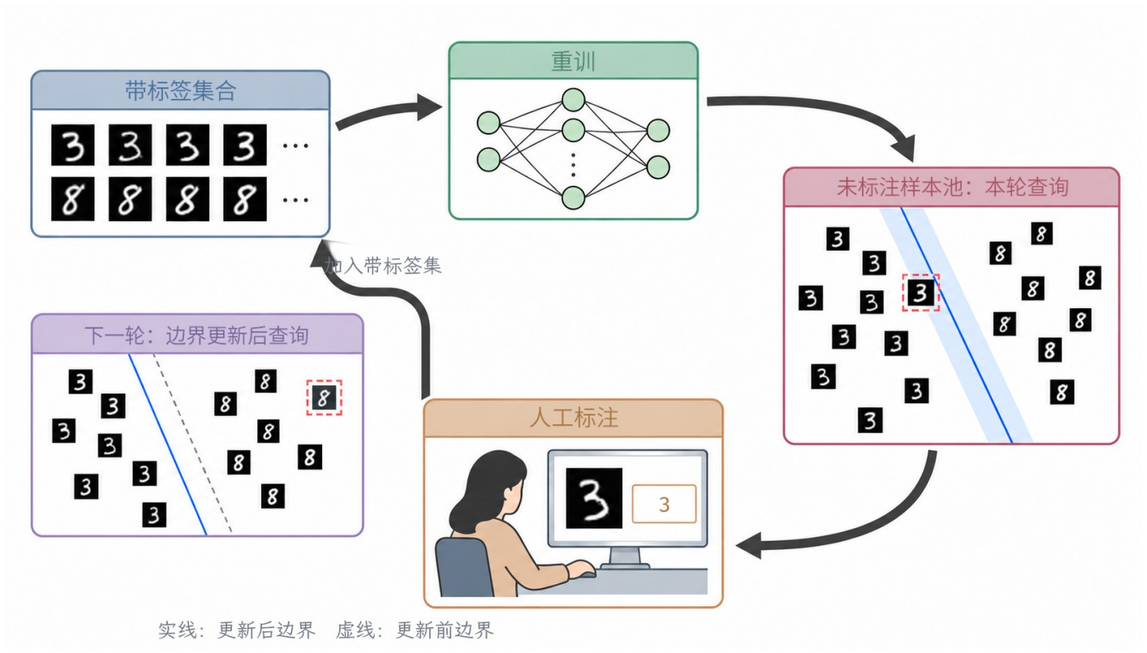


## 当前 · 7dd5e395

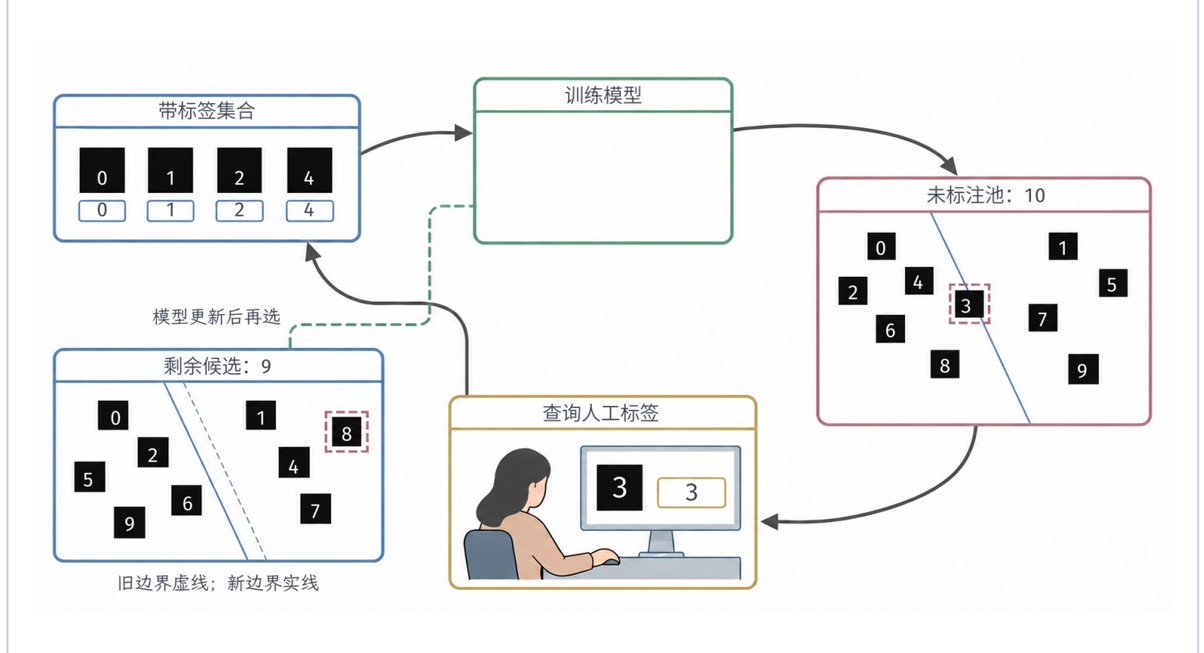


当前图注：池式主动学习的教学示意。蓝色直线表示当前模型的决策边界，红色虚线方框标出本轮查询的数字3。标注者返回标签后，样本并入带标签集合，用于重训模型，未标注池由10个候选减为9个。左下方的虚线保留更新前的边界，实线表示更新后的边界；虚线方框标出的数字8是下一轮查询对象。查询预算限制循环。数字字形、二维位置和边界均为教学构造，不表示实测分布或选样收益；数字样本的外观不等同于供模型使用的类

# 018 范式简介

fig:continual-learning-timeline | 当前与提交前不同

## 提交前 · fbb26aec

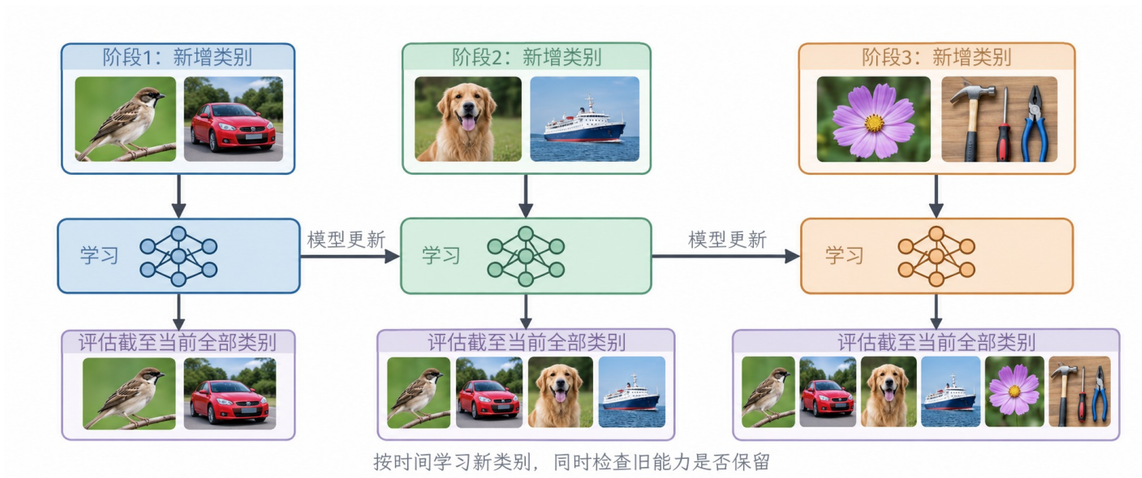


## 当前 · 7dd5e395

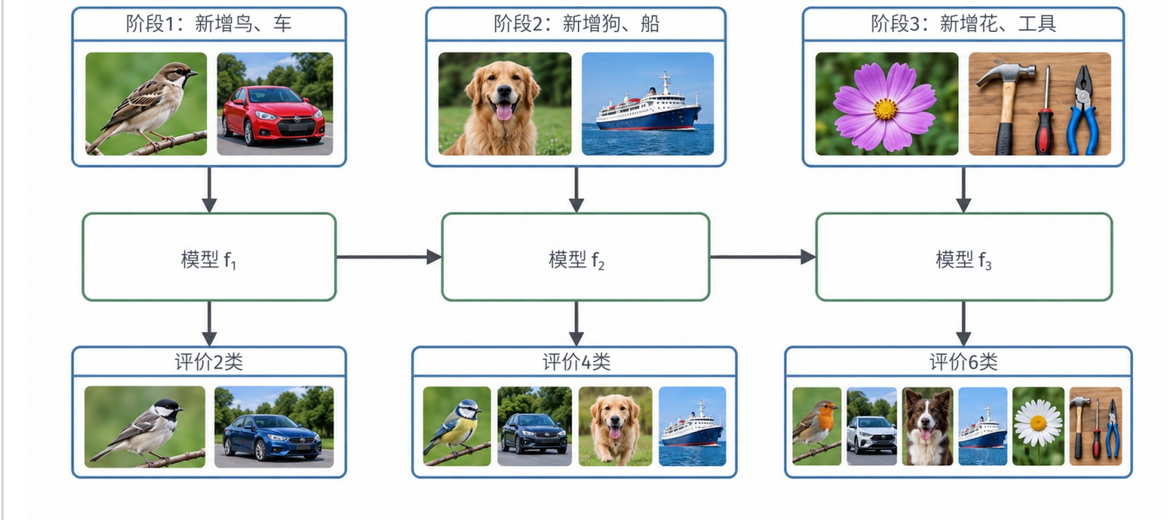


当前图注：持续学习的类别增量过程。不同类别的图像按阶段到来；每个阶段都要学习新增类别，并在截至当前出现过的全部类别上检查能力。横向箭头串接各阶段的模型更新，下方评价范围依次覆盖2、4、6类，预测时不给阶段身份。样本图片为教学构造，模型框不对应精确记忆容量。

图片保持原比例；同框适配，仅用于比较独立图。完整图注与源路径见网页及清单。

# 019 范式简介

fig:multi-task-learning-process | 当前与提交前不同

## 提交前 · fbb26aec

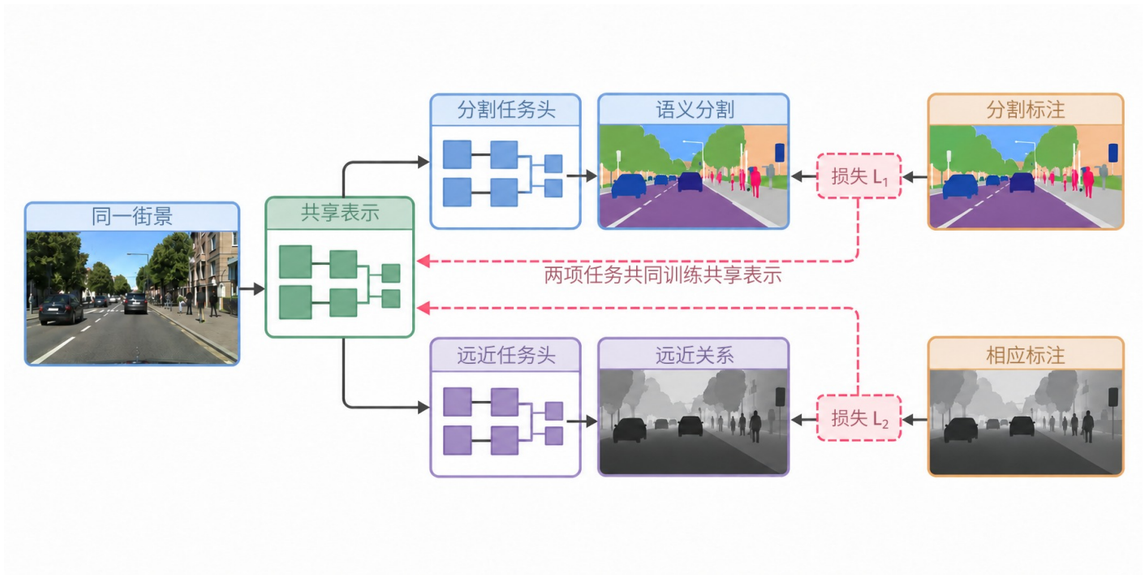


## 当前 · 7dd5e395

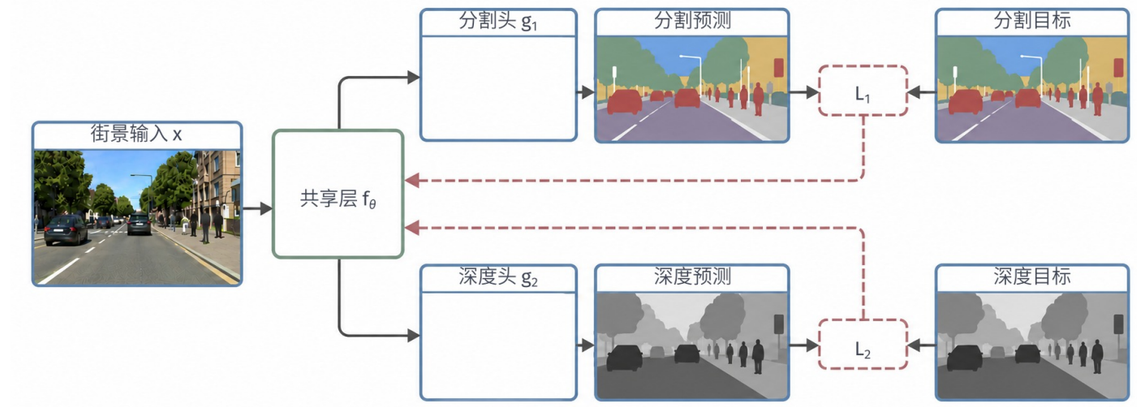


当前图注：多任务学习的过程示意。同一街景及不同任务的标注共同影响共享表示，系统分别输出 语义区域和远近关系；两个结果都是概念示意，不是论文实验的实际输出。

# 020 范式简介

fig:transfer-learning-process | 当前与提交前不同

提交前 · fbb26aec

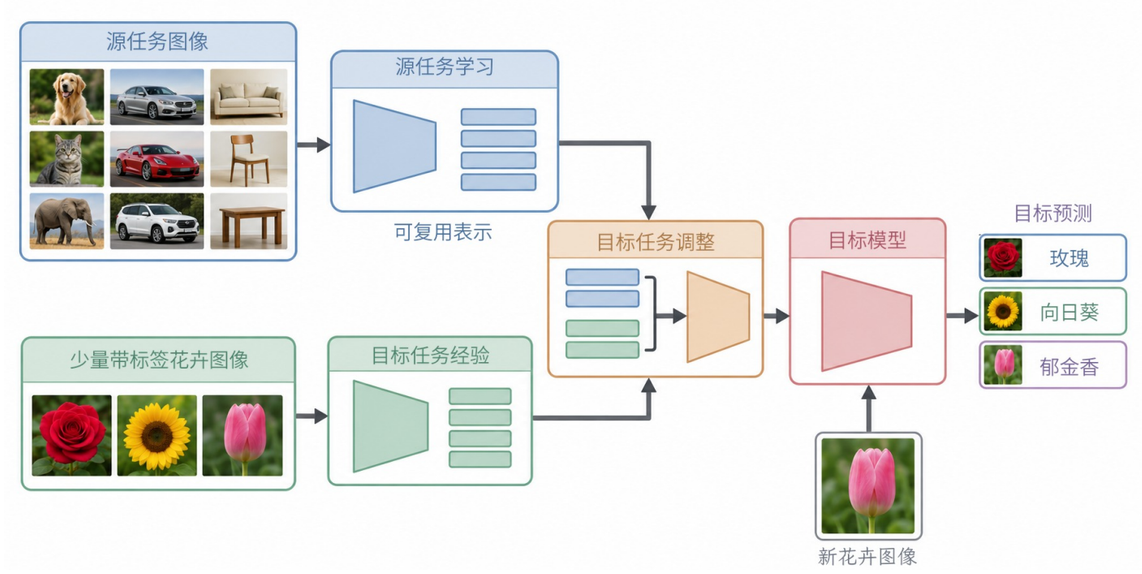


当前 · 7dd5e395

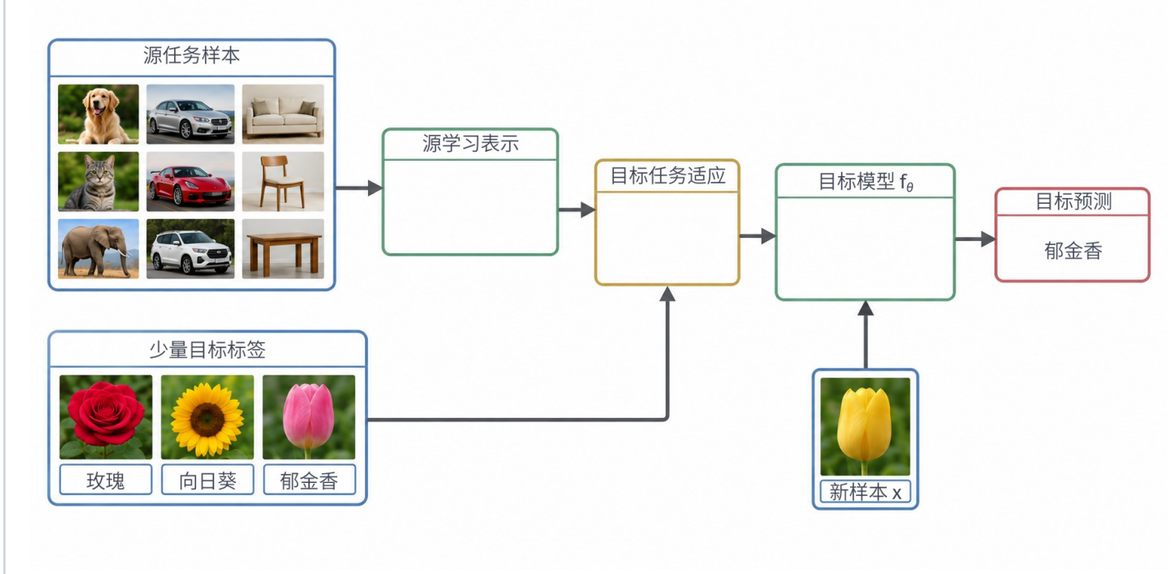


当前图注：迁移学习的过程示意。通用图像任务形成可复用的表示，目标任务再用少量花卉标签调整 这些知识，最后识别新的花卉照片；来源知识与目标数据共同决定结果。

# 021 范式简介

fig:meta-learning-process | 当前与提交前不同

## 提交前 · fbb26aec

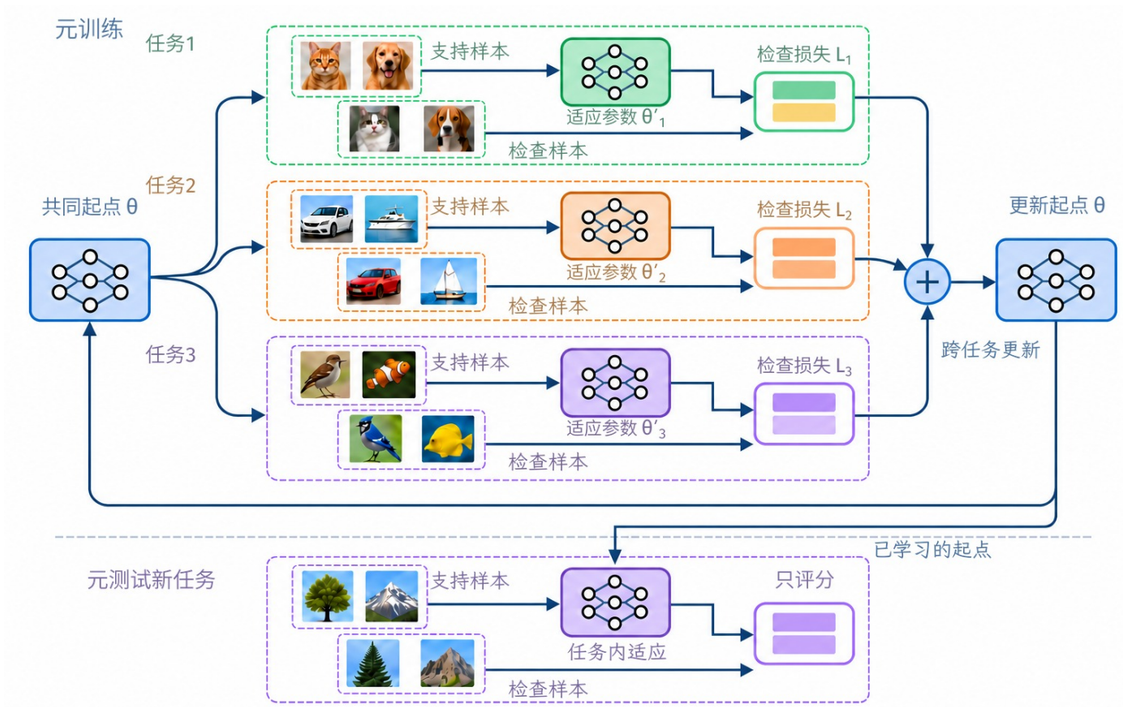


## 当前 · 7dd5e395

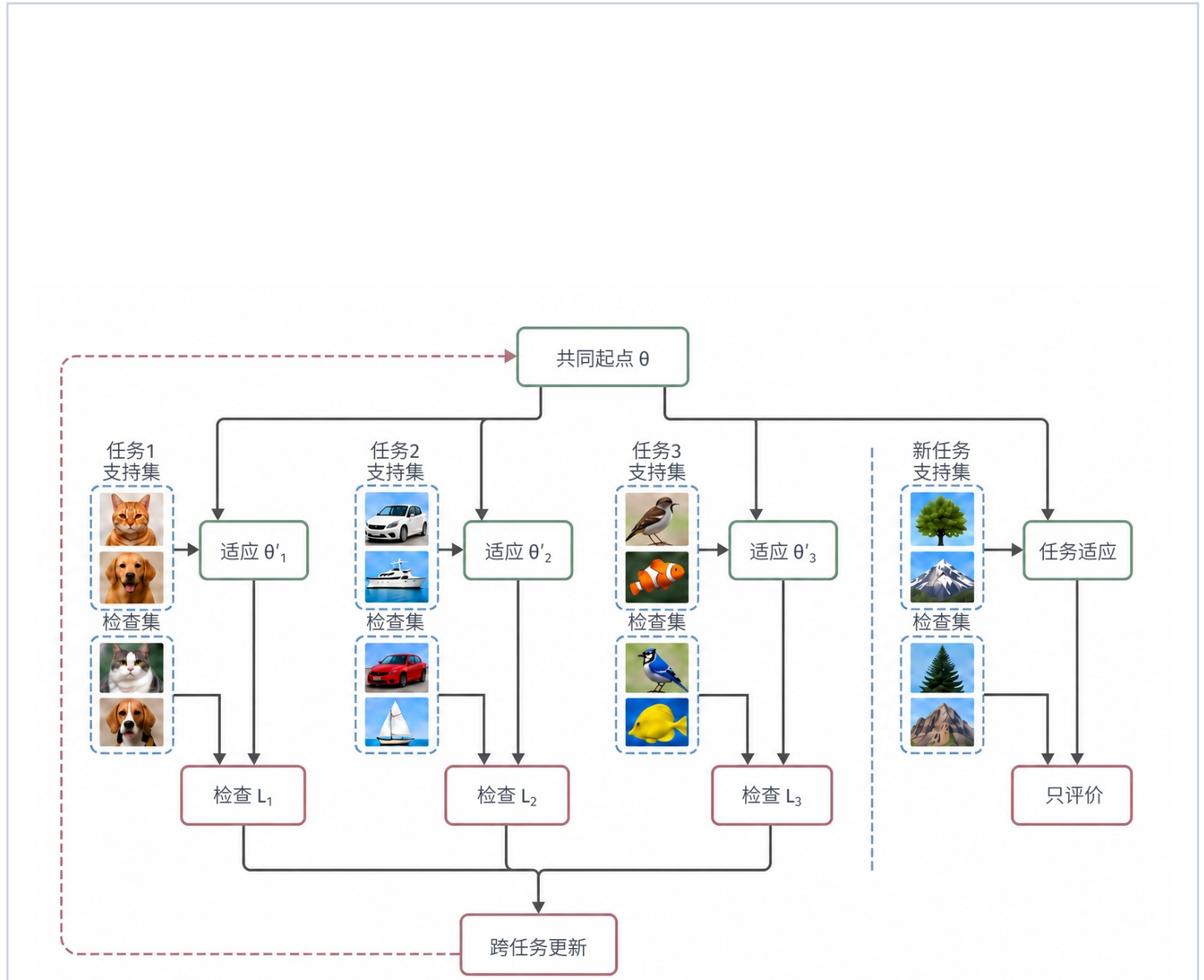


当前图注：任务内适应与跨任务更新。元训练任务从共同起点出发，用任务内适应样本得到参数'_，再汇总另一批检查样本上的损失L_来更新起点；两批样本都参与元训练。未参加元训练的新任务只用少量适应样本调整参数，最终检查评分不回传共同起点。任务与图像样本为教学构造，不是Omniglot原始样本。

# 022 范式简介

fig:online-feedback-order | 当前与提交前不同

## 提交前 · fbb26aec

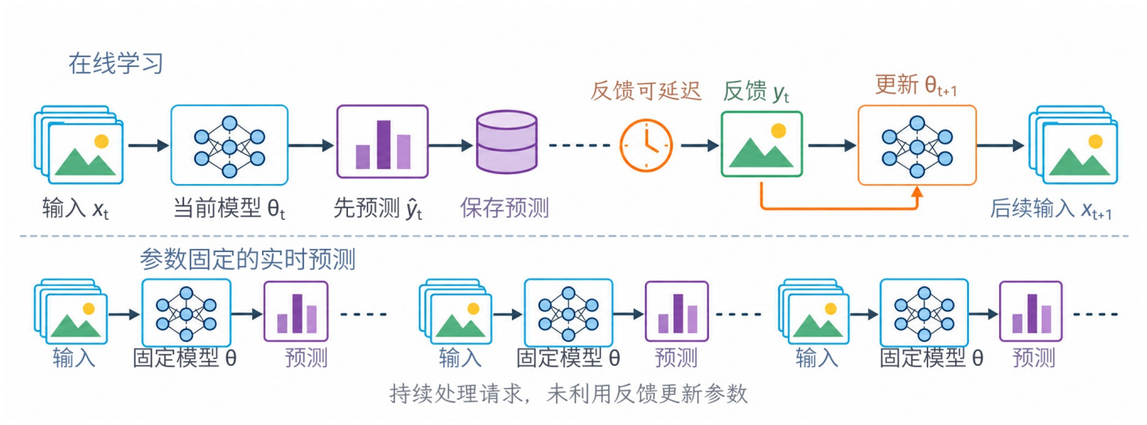


## 当前 · 7dd5e395

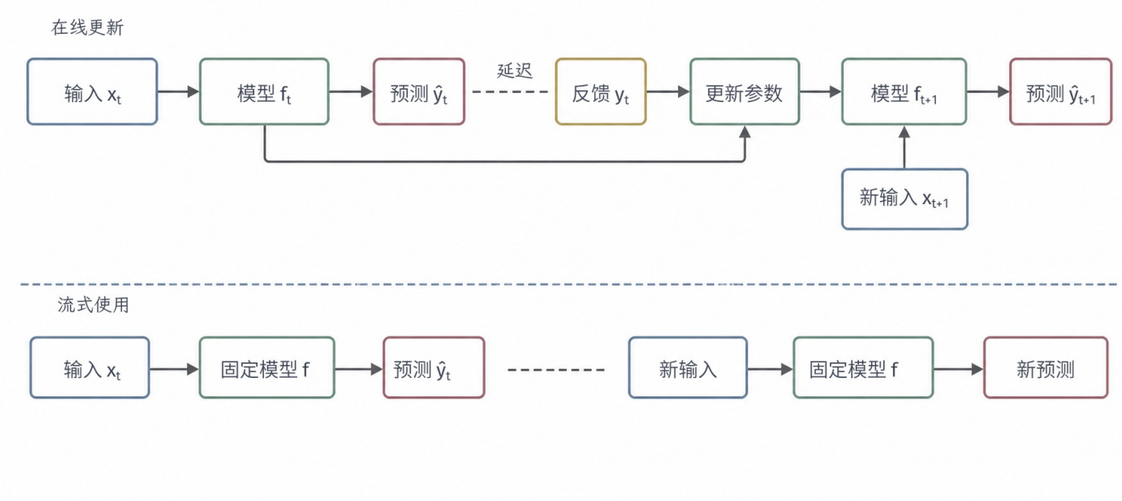


当前图注：在线学习先用当前模型预测并保存此时尚未看到答案的结果，反馈可以延迟或按小批次到达，随后更新只作用于后续输入。下方对照只用固定参数持续响应的实时预测；请求持续到来本身不构成在线学习。

# 023 范式简介

fig:federated-learning-process | 当前与提交前不同

## 提交前 · fbb26aec

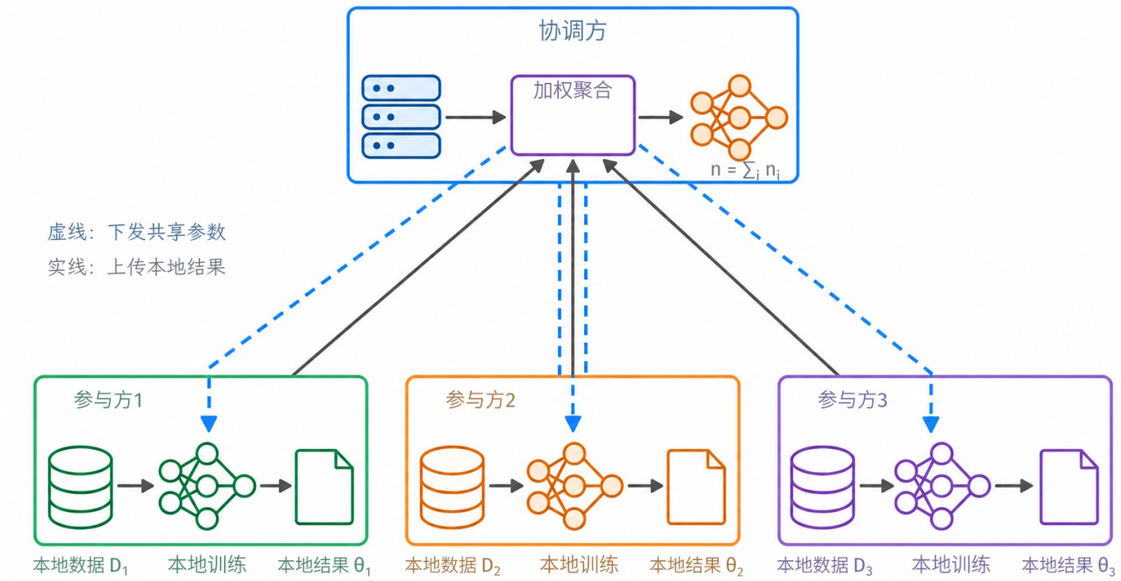


## 当前 · 7dd5e395

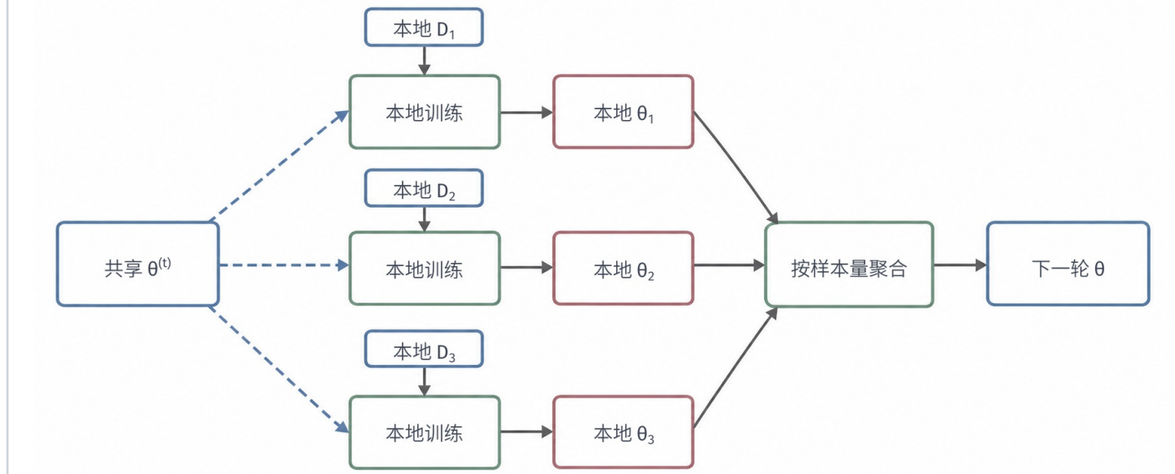


当前图注：中心协调式联邦学习的一轮通信。协调方向三个示意参与方下发同一组共享参数^(t)；各方使用自己的本地记录集D_i训练，得到本地参数_i^(t+1)并上传。协调方按正文所述的样本量权重形成下一版本^(t+1)，下一轮再统一下发。参与方数量为教学示意；原始记录留在本地，但模型更新仍可能泄露信息，联邦组织方式本身不提供隐私保证。

图片保持原比例；同框适配，仅用于比较独立图。完整图注与源路径见网页及清单。

# 024 范式简介

fig:paradigm-combination-alphago | 当前与提交前不同

## 提交前 · fbb26aec

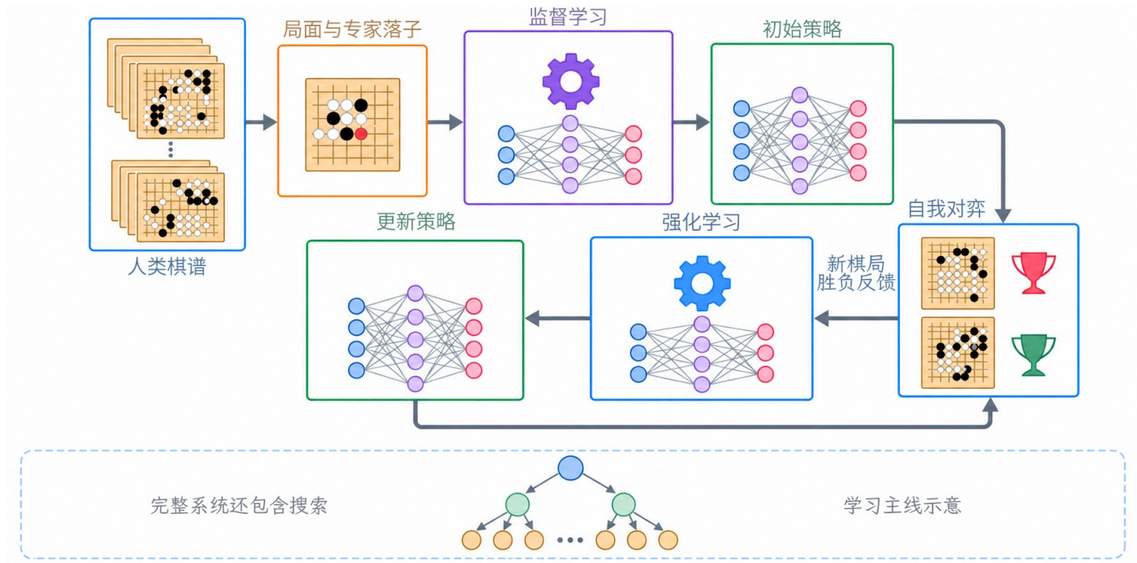


## 当前 · 7dd5e395

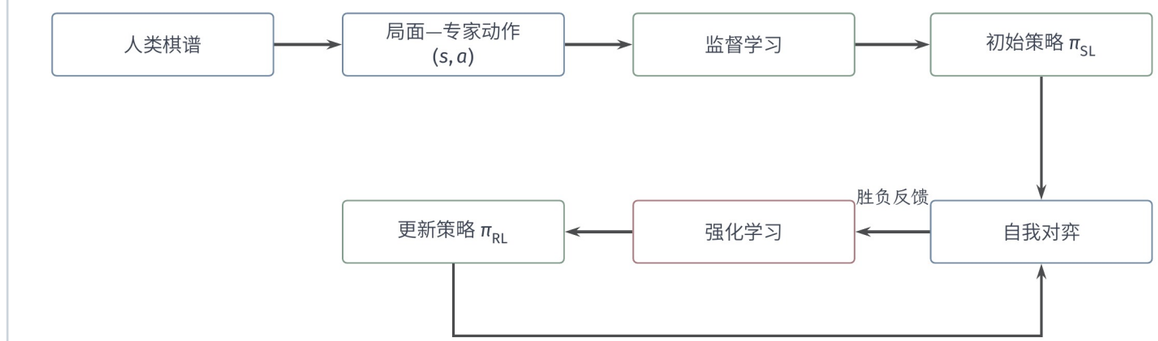


当前图注：AlphaGo学习主线的简化示意。人类棋谱为监督学习阶段提供局面与专家落子；得到初始策略后， 自我对弈产生新棋局与胜负反馈，用于强化学习阶段。完整系统还包含价值网络与搜索等组件。

# 025 机器学习理论基础

fig:learning-two-randomness | 当前与提交前不同

提交前 · fbb26aec

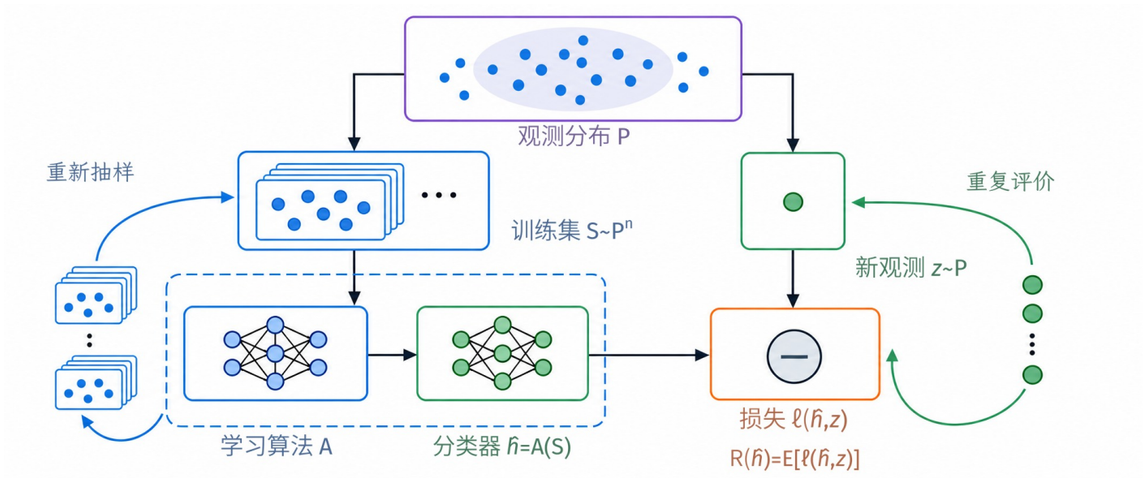


当前 · 7dd5e395

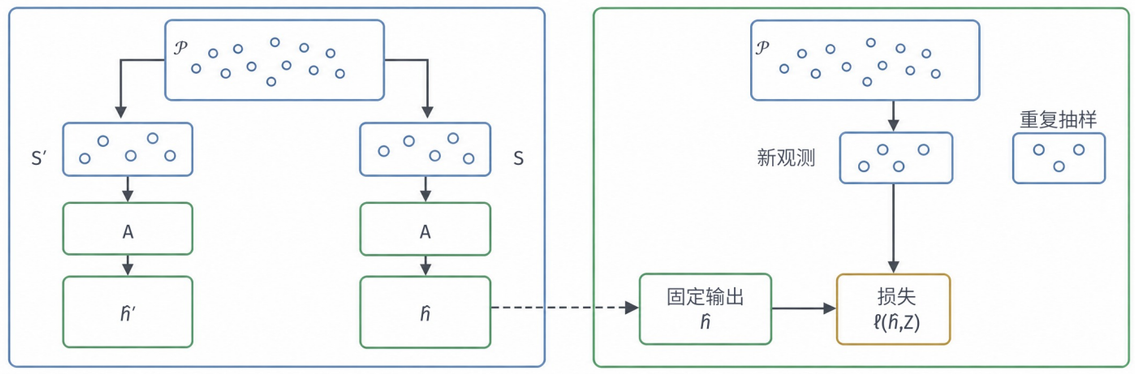


当前图注：两层随机性的评价对象。固定训练输出后，右侧新观测的平均损失给出期望风险；左侧重新抽样则改变输出，学习保证控制这种变化造成高风险结果的概率。

# 026 机器学习理论基础

fig:learning-no-free-lunch | 当前与提交前不同

## 提交前 · fbb26aec

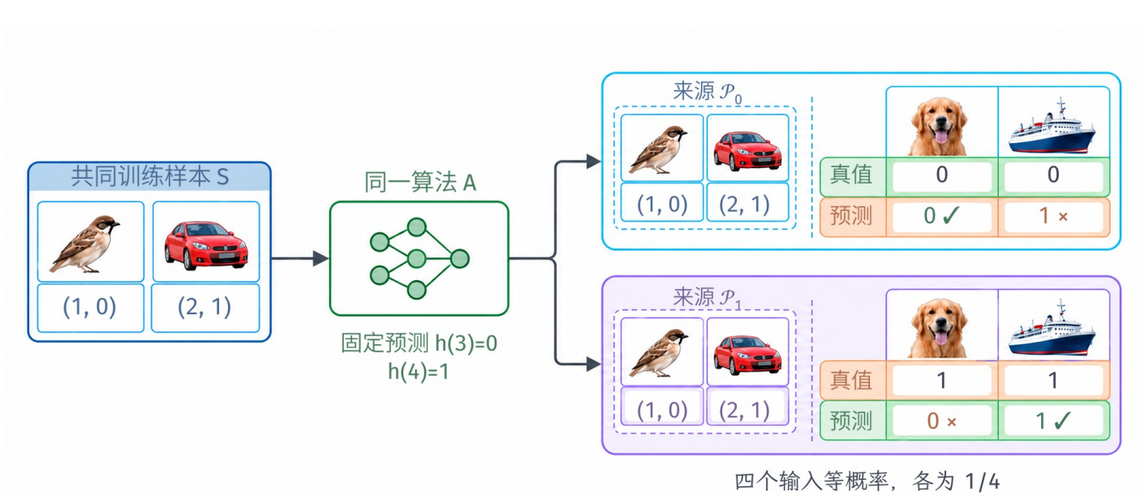


## 当前 · 7dd5e395

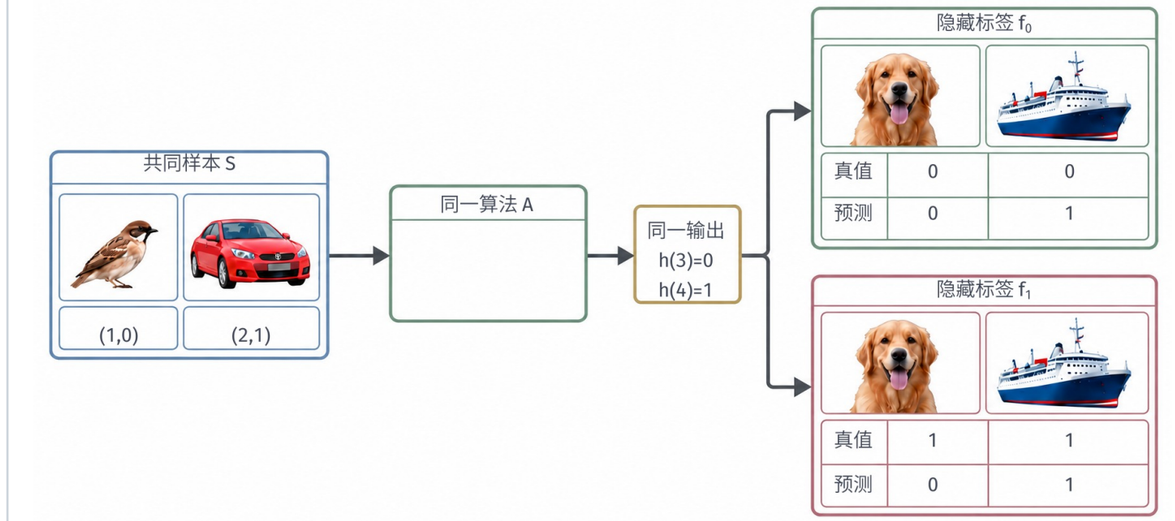


当前图注：相同样本与两套隐藏标签。鸟、汽车、狗、船分别表示编号1至4，每个概率为1/4；两套来源在已见编号1、2上同为0、1，未见编号3、4则分别全为0或全为1。图示输出h(3)=0,h(4)=1在每套来源各错一个点。固定样本与内部随机数后输出相同，任意二元预测在每个未见点的两份损失相加为1，故风险之和至少1/2。这里展示固定样本的歧义，下文再证明随机抽样下的固定困难分布。

# 027 机器学习理论基础

fig:approximation-estimation-error | 当前与提交前不同

提交前 · fbb26aec

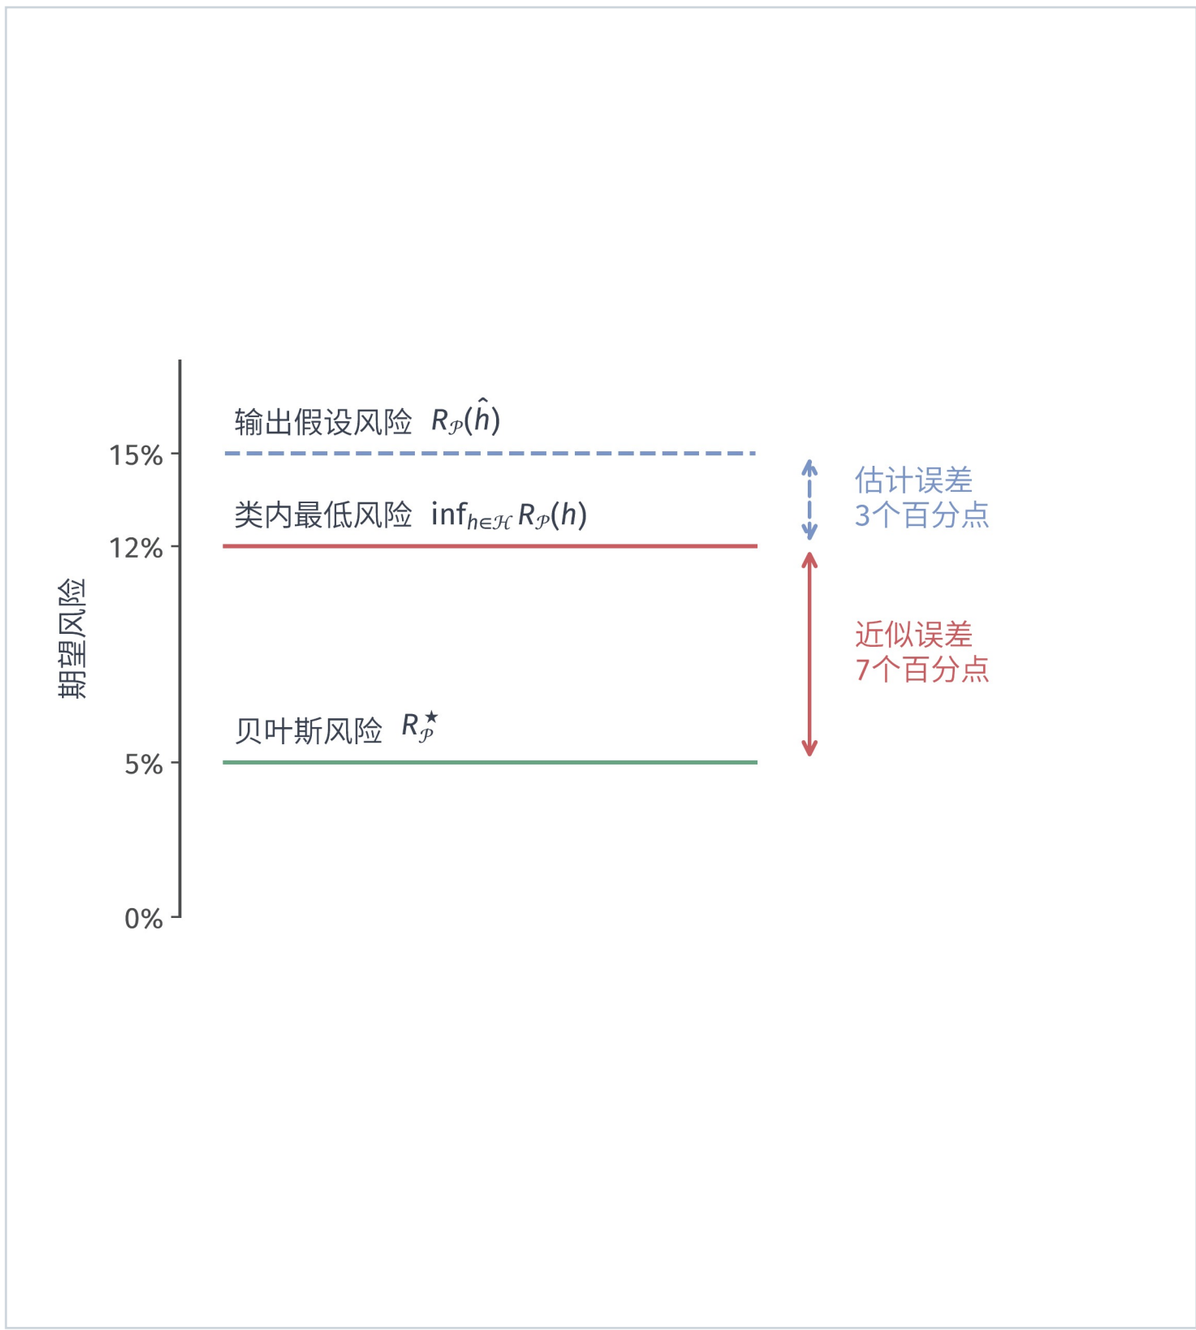


当前 · 7dd5e395

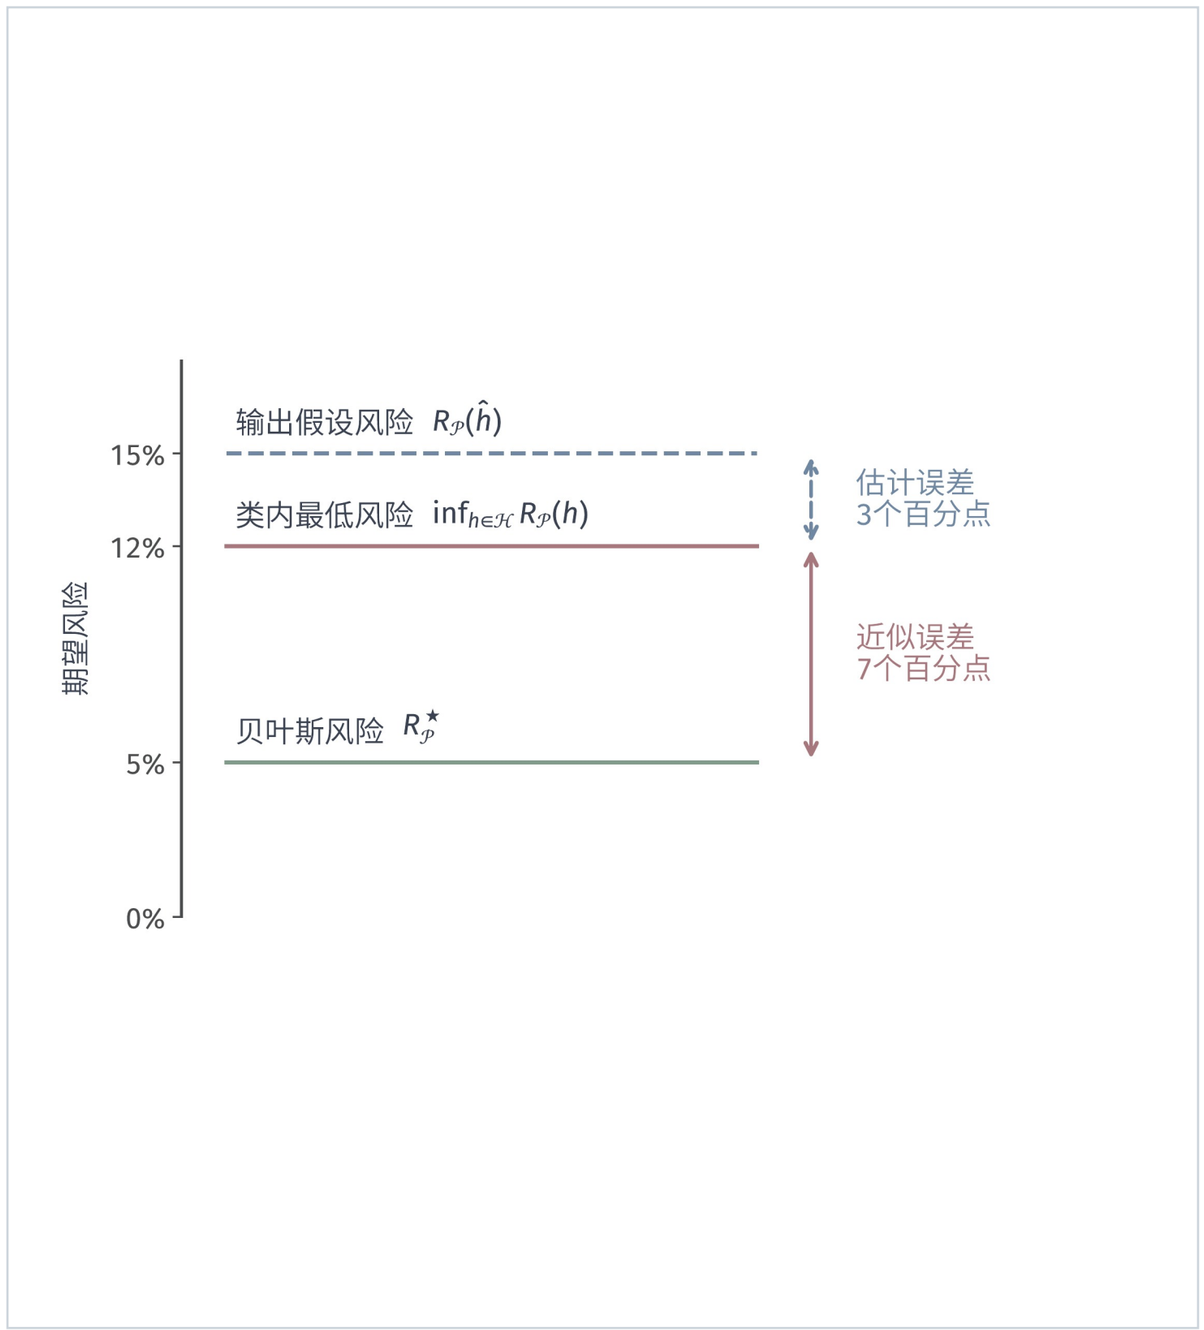


当前图注：风险的两段差距。教学设定中，贝叶斯风险为5\%，阈值空间最低风险为12\%，输出风险为15\%。前两者相差7个百分点，为实线表示的近似误差；后两者相差3个百分点，为虚线表示的估计误差。

fig:learning-model-selection | 当前与提交前不同

提交前 · fbb26aec

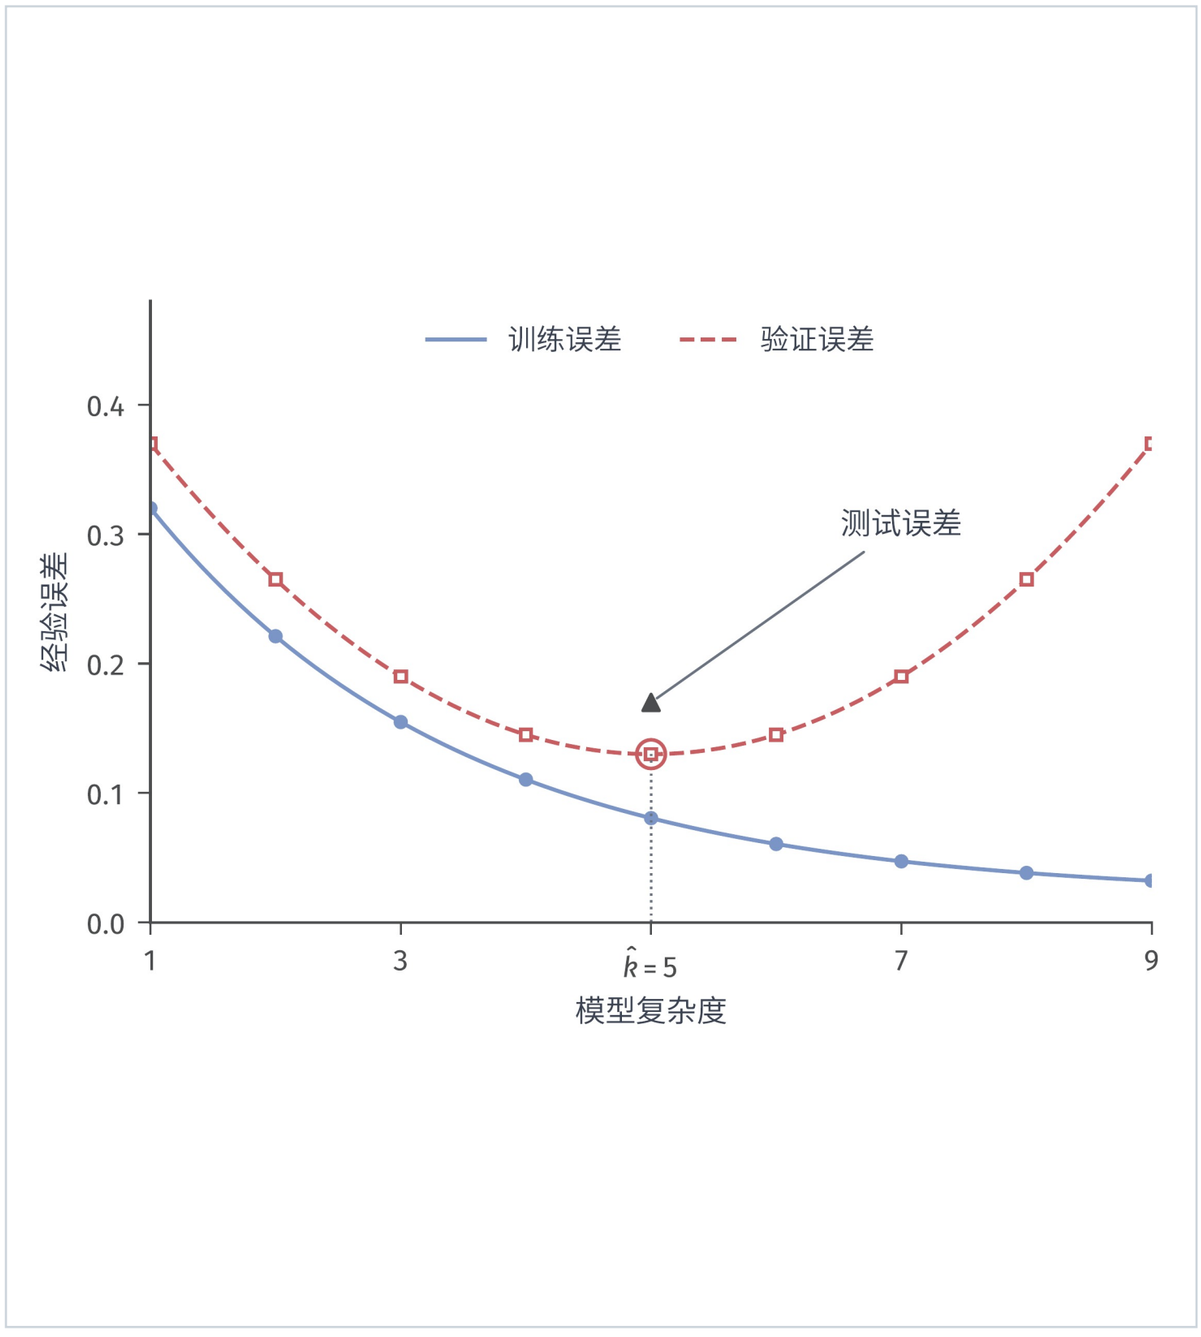


当前 · 7dd5e395

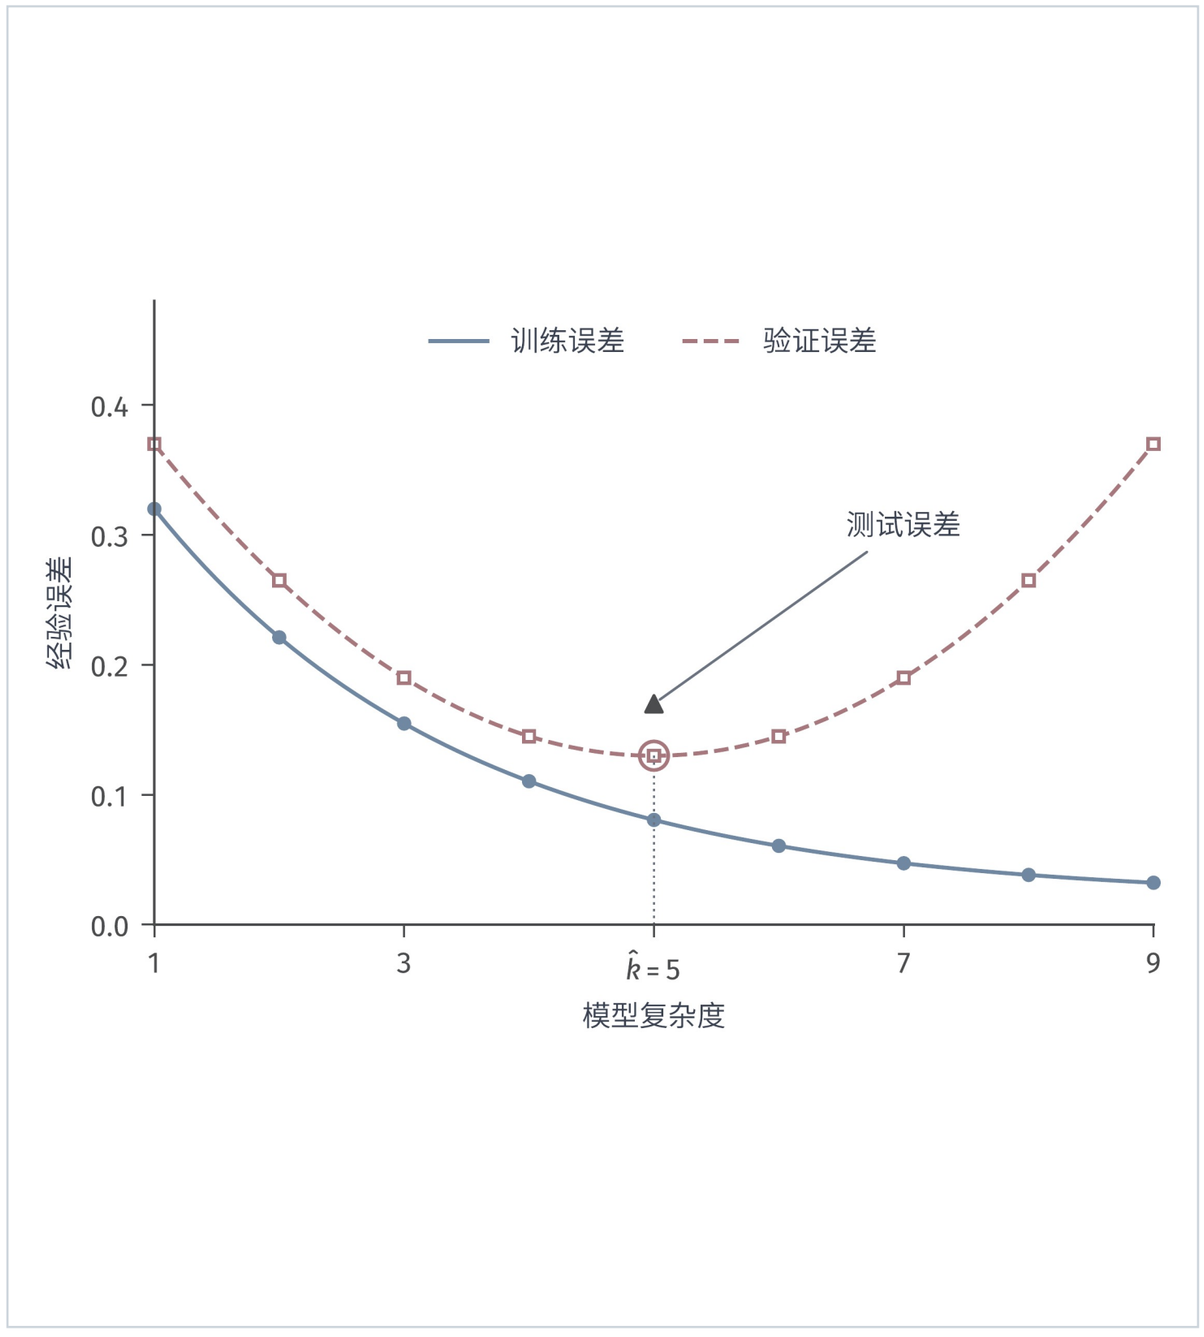


当前图注：教学示意中的验证选择与独立测试。实线圆点为训练误差，虚线方块为验证误差，圆环的最低验证误差确定 k。三角形仅为锁定模型后的一次测试评价，未参与选择，故不连成测试曲线。所有数值均为构造示意。

# 029 机器学习理论基础

fig:learning-theory-research-problems-map | 当前与提交前不同

提交前 · fbb26aec

当前 · 7dd5e395

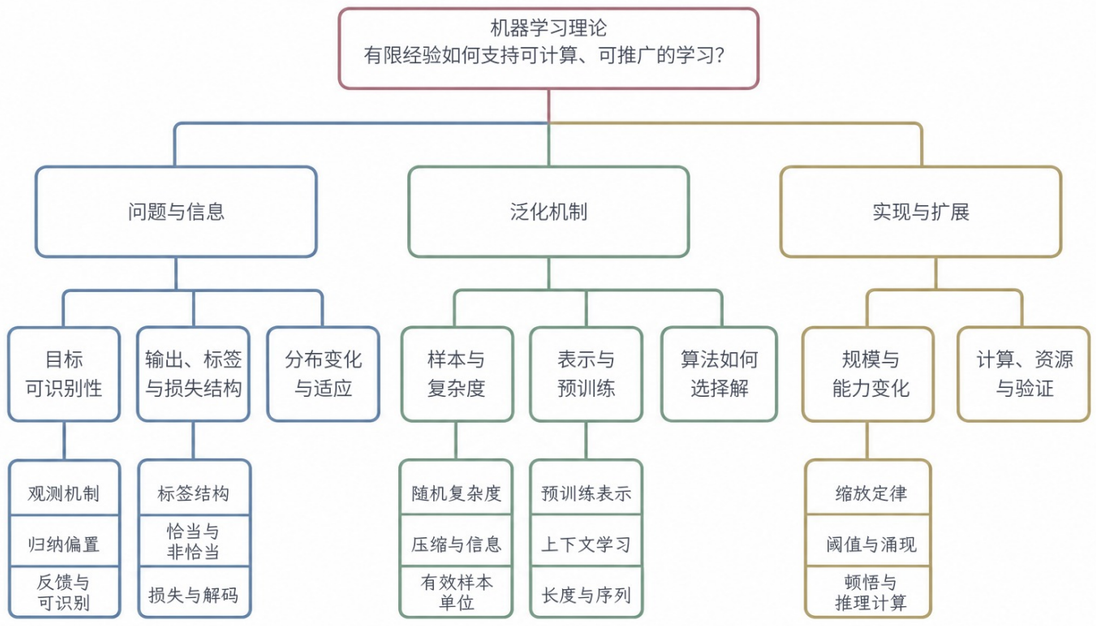


当前图注：学习理论的问题与条件地图。顶层询问有限经验怎样支持可计算且可推广的学习；下方以蓝、绿、黄区分问题与信息、泛化机制、实现与扩展三组，这三组共列八个相互制约的问题。末端列表给出部分代表课题，不表示完整分类；连线表示讨论层次，不表示推导或因果关系。

# 030 二分类学习的可学习性

fig:learning-uniform-convergence | 当前与提交前不同

提交前 · fbb26aec

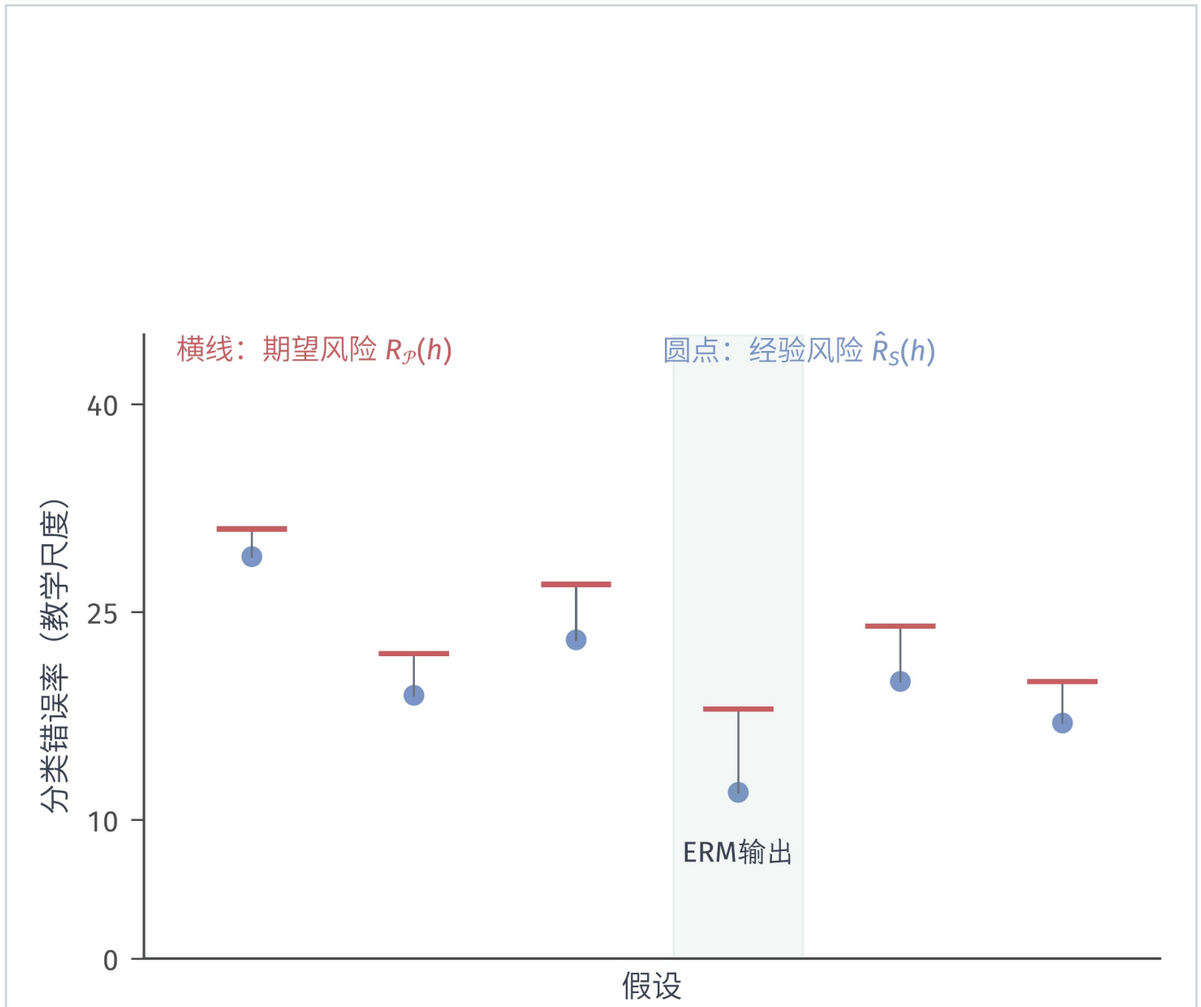


当前 · 7dd5e395

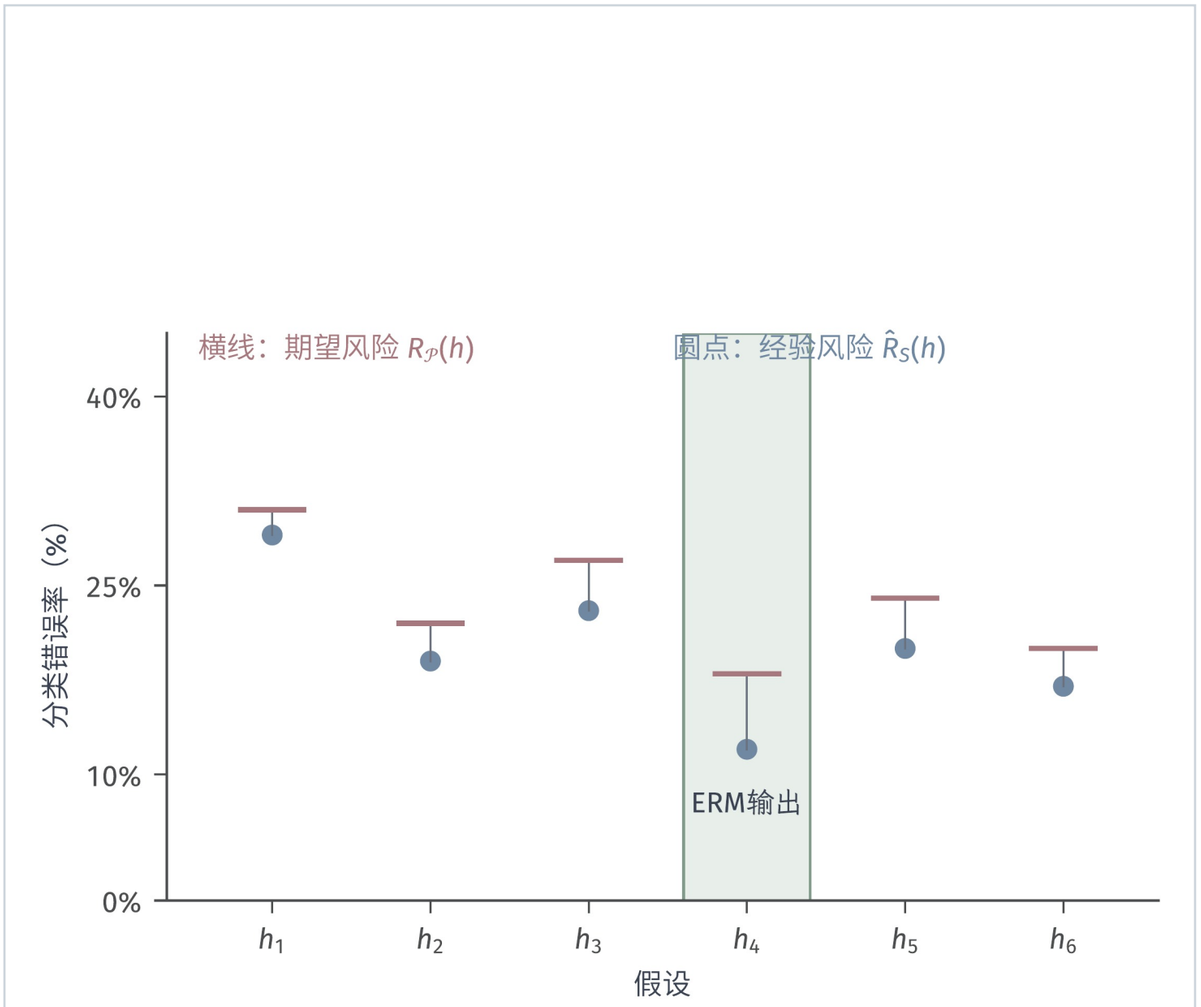


当前图注：单个风险估计与共同保证。竖线连接各假设的经验风险与期望风险；只限制其中一条线，不能覆盖ERM在框中选择的输出。限制全部竖线后，这个数据依赖输出也落在保证内。

# 031　多分类学习的可学习性

fig:learning-theory-ds-neighbors | 新增 / 无提交前对应图

提交前・fbb26aec

提交前没有对应图片

当前・7dd5e395

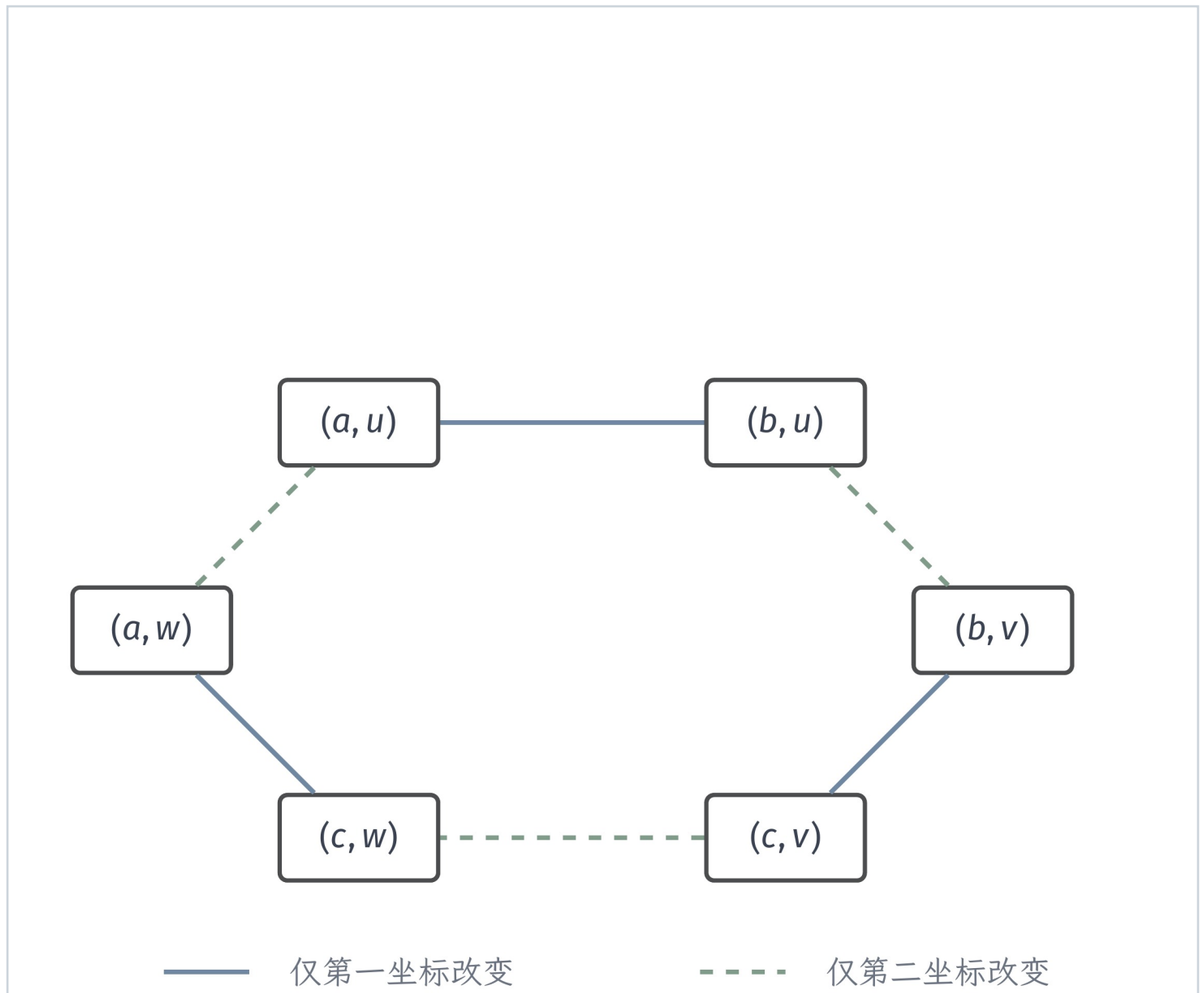


当前图注：六种预测的坐标邻接环。顶点为上文的六个向量，蓝色实线仅改变第一坐标，绿色虚线仅改变第二坐标；边没有方向。每个顶点在两个坐标上分别有邻居，却不存在固定两对标签的完整四种组合。因而这个两输入函数类的Natarajan维为1，后文分析的DS维为2；它仍是可学习的有限类，不能单独证明不可学习性。

# 032 一般学习的可学习性

fig:learning-stability | 当前与提交前不同

## 提交前 · fbb26aec

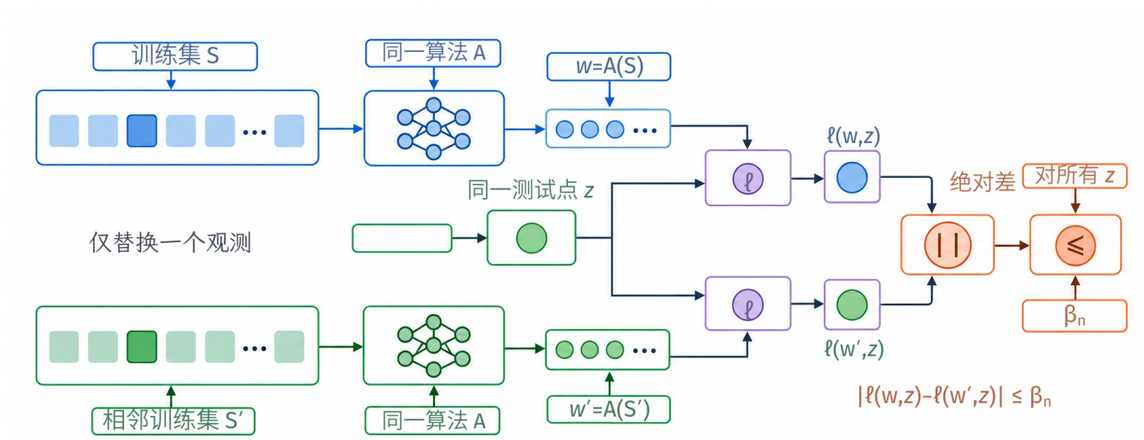


## 当前 · 7dd5e395

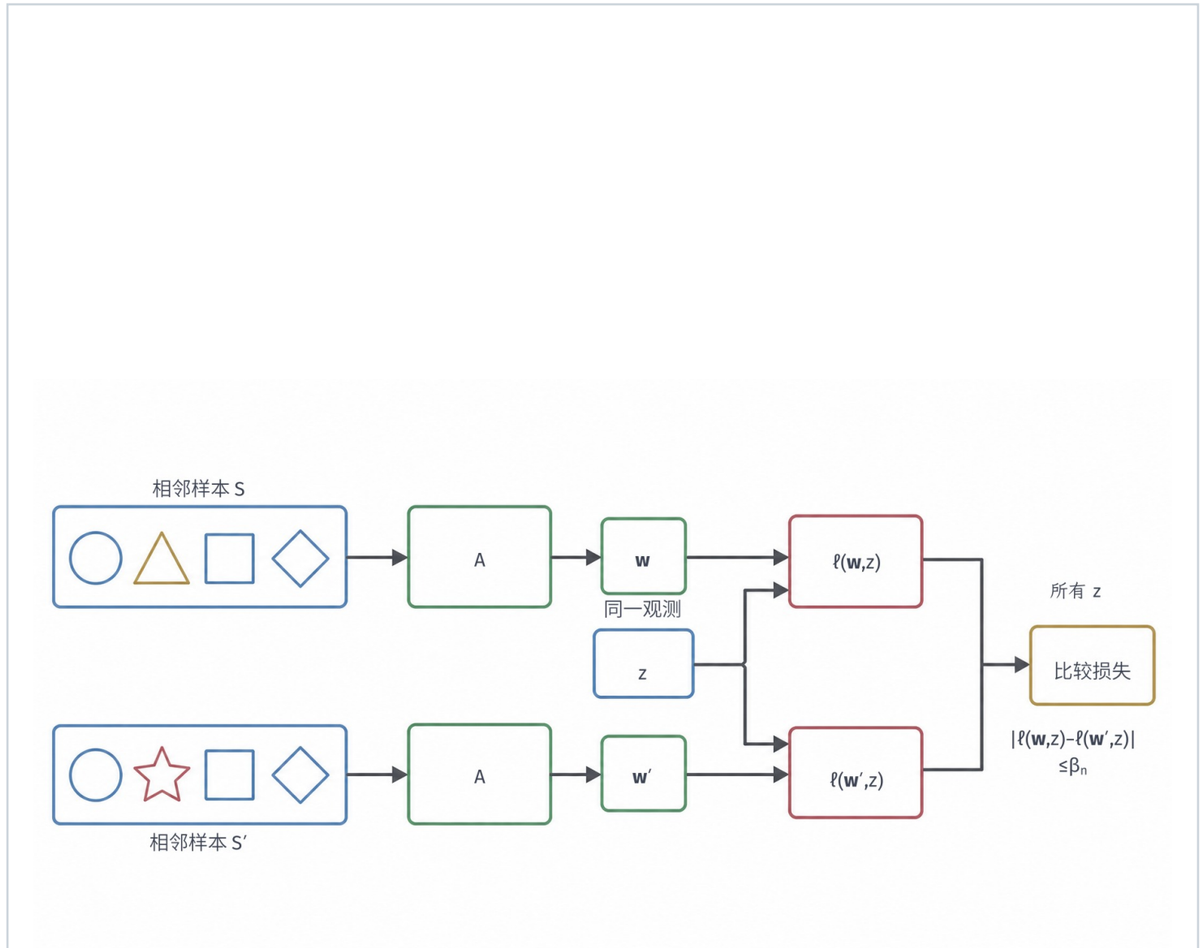


当前图注：算法稳定性的相邻样本实验。两批样本只替换一个观测，同一算法分别输出 w=A(S)与 w'=A(S')。两次输出在同一测试点z上计算损失，再比较绝对差； 均匀稳定性要求所有这样的损失差都不超过 _n。图中的比较对象是损失，不是参数距离。

# 033 一般学习的可学习性

fig:conditional-information | 当前与提交前不同

提交前 · fbb26aec

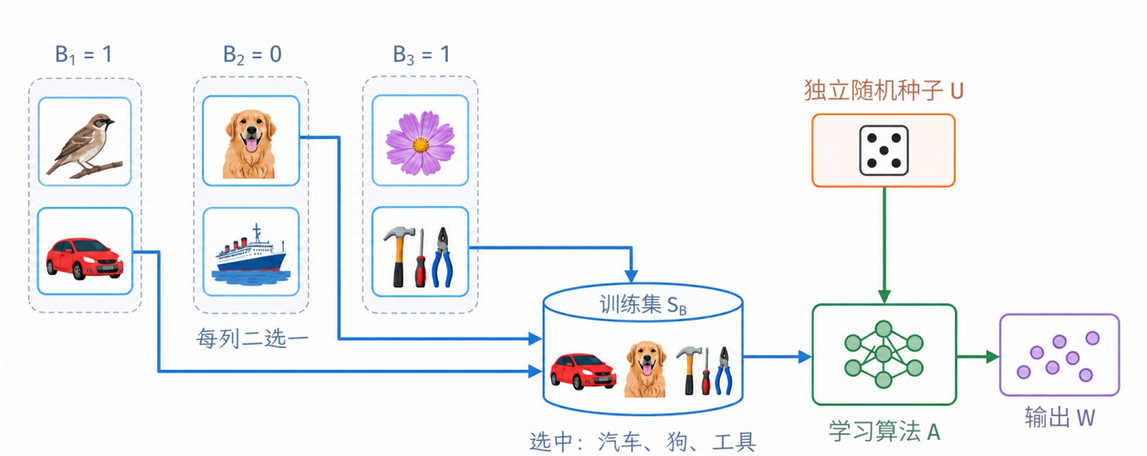


当前 · 7dd5e395

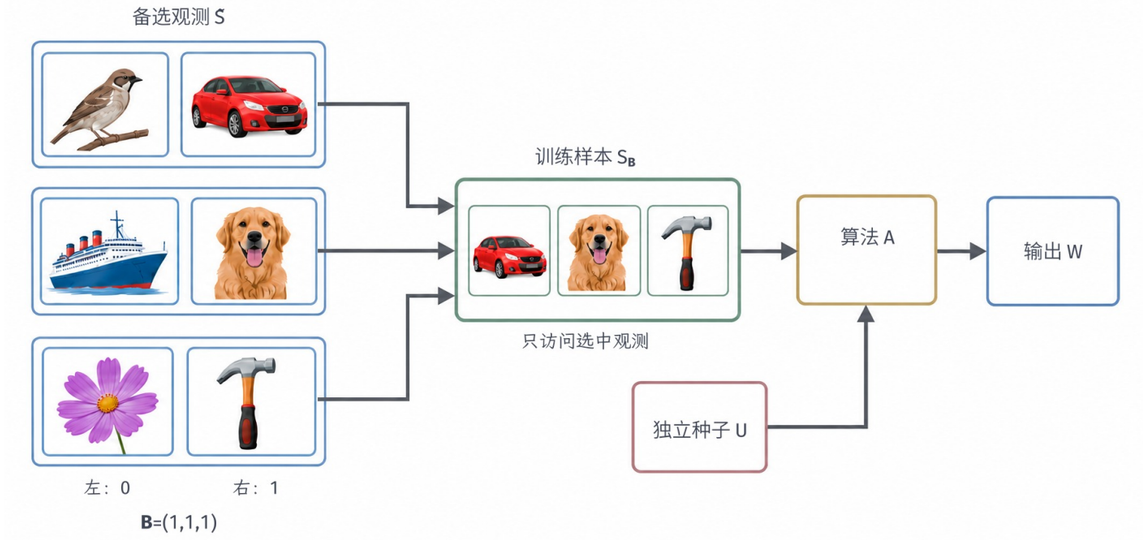


当前图注：条件互信息的抽样构造。每行有两个独立观测，左、右分别编号0、1；选择变量决定哪一个进入训练样本。图中 B=(1,1,1)，箭头与训练集中的内容同时标出选中的观测。算法接收选中的三个观测与独立随机种子U；条件互信息衡量已知全部六个观测时，输出对选择变量揭示了多少信息。

图片保持原比例；同框适配，仅用于比较独立图。完整图注与源路径见网页及清单。

# 034 一般学习的可学习性

fig:learning-risk-routes | 当前与提交前不同

## 提交前 · fbb26aec

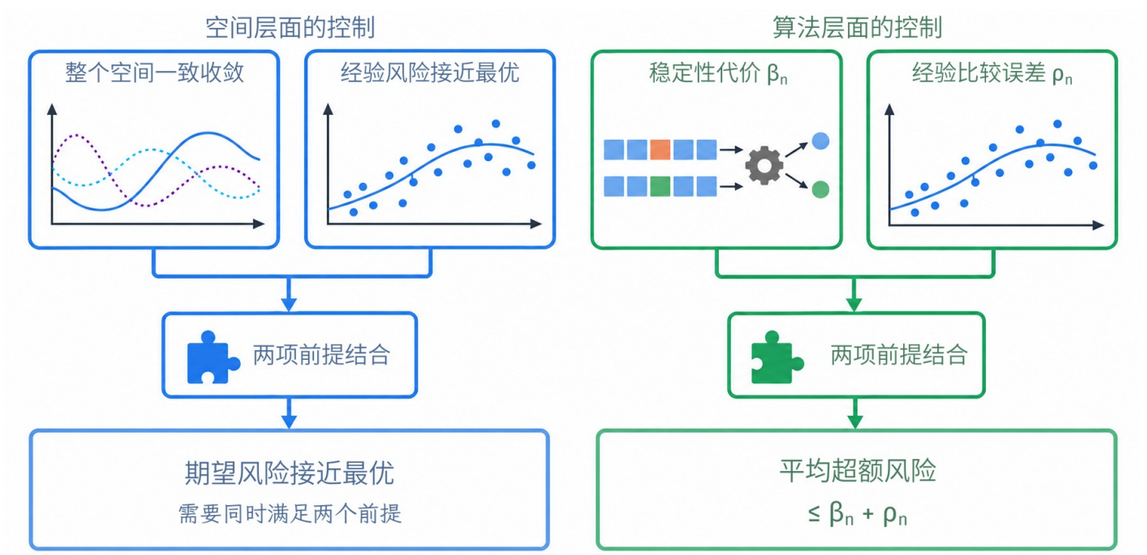


## 当前 · 7dd5e395

当前图注：期望风险的两条分析路线。左侧同时控制整个决策空间，右侧控制算法输出的期望 泛化差；两条路线都要结合经验最优性。右侧用_n泛指所选稳定性定理提供的代价项。

# 035 一般学习的可学习性

fig:stability-curvature | 当前与提交前不同

## 提交前 · fbb26aec

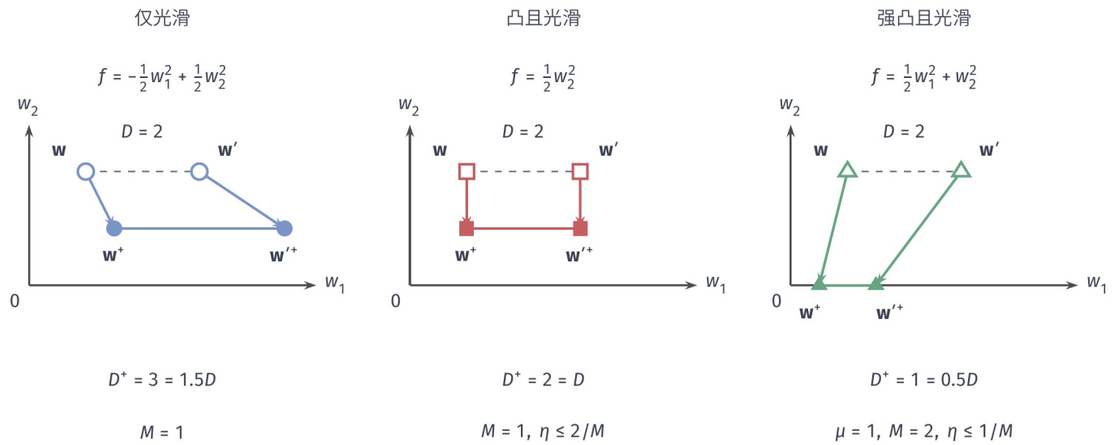


## 当前 · 7dd5e395

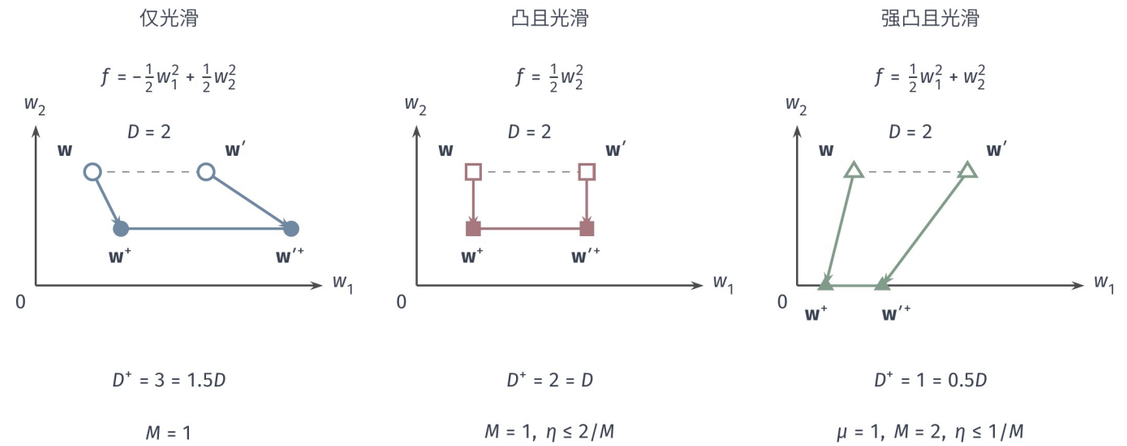


当前图注：同一梯度更新如何影响参数距离。三个参数平面使用相同尺度，初值均为 w=(1,2)^、 w'=(3,2)^，步长均为=1/2。 空心标记表示初值，实心标记表示 w^+= w- f( w)及 w'^+；箭头表示各自的梯度步，虚线和实线连接更新前后的两点。 图中二次函数的梯度步给出精确距离D^+=3,2,1，并非一般情形的距离等式。 凸且M-光滑时，2/M保证不扩张；满足本章强凸光滑

# 036 深度学习的可学习性

fig:learning-deep-selection | 当前与提交前不同

提交前 · fbb26aec

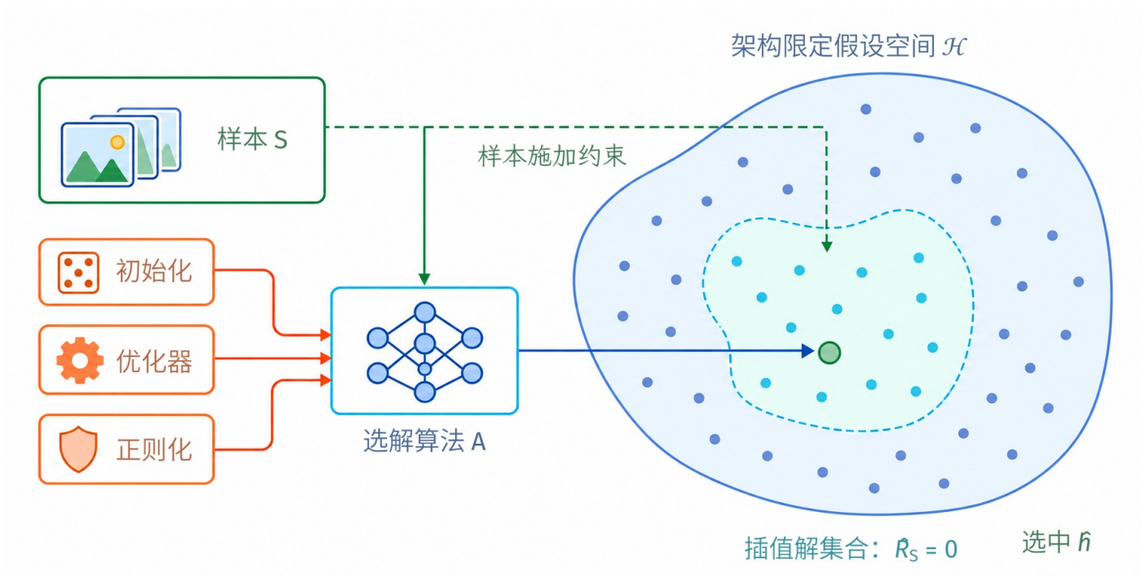


当前 · 7dd5e395

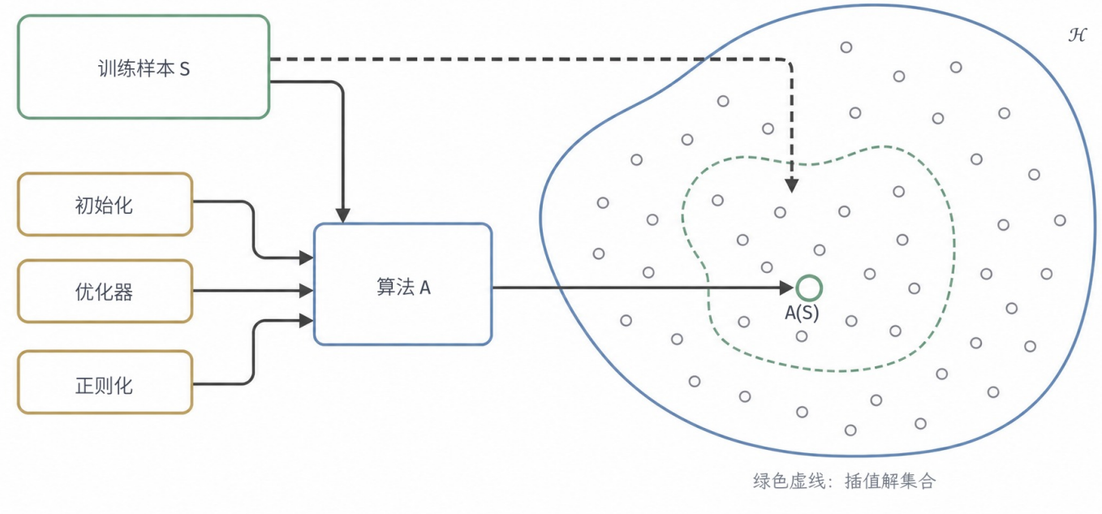


当前图注：架构、样本和算法分别限定不同对象。外层是假设空间，内层是当前样本上经验风险 为零的插值解集合；虚线表示样本施加的约束，实线表示算法的输入与输出。初始化、优化器 和正则化参与选解。强调点仅示意算法选出一个插值解，不保证任意算法都实现插值；集合 的形状和大小没有数值含义，插值也不保证期望风险小。

# 037 深度学习的可学习性

fig:learning-double-descent | 当前与提交前不同

提交前 · fbb26aec

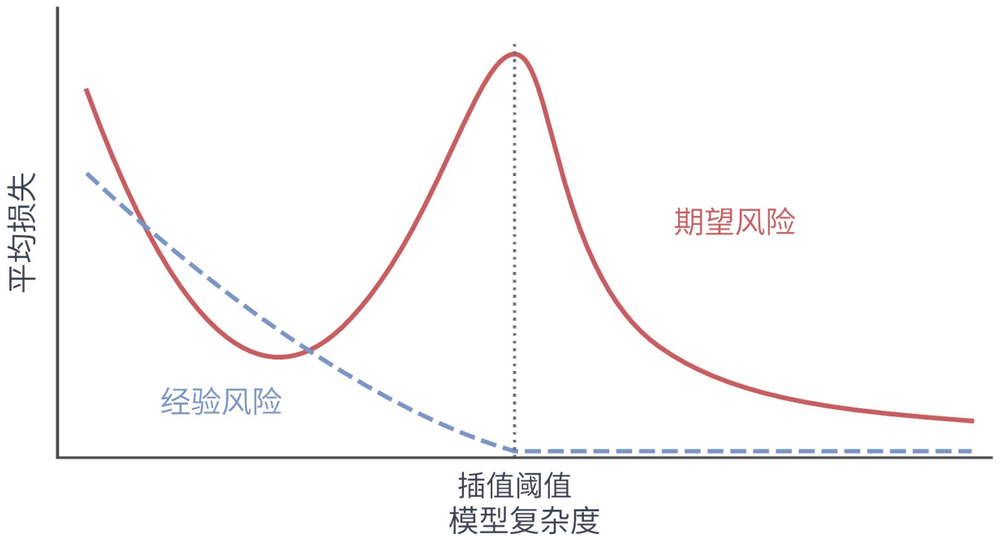


当前 · 7dd5e395

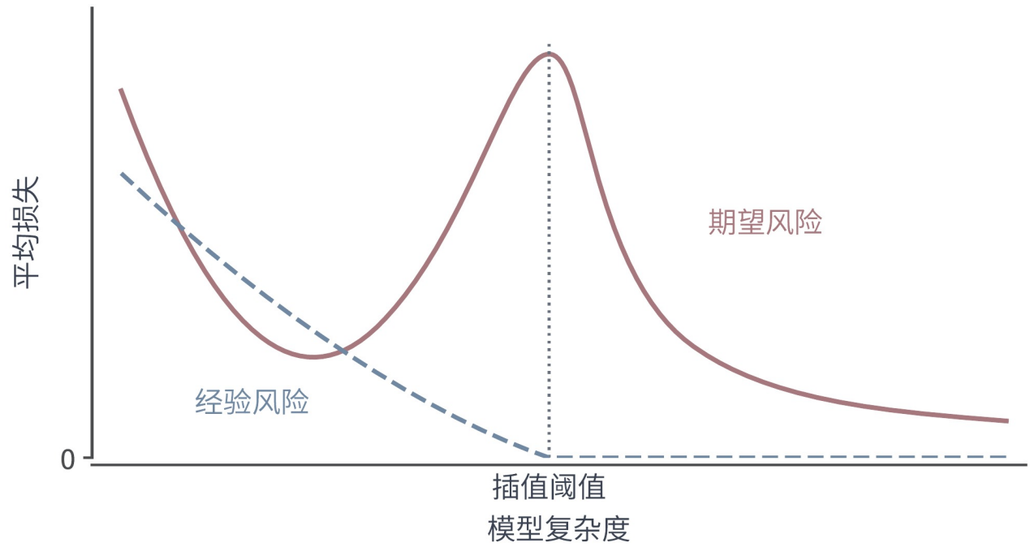


当前图注：双重下降的定性示意。虚线表示经验风险，实线表示一种可能出现的期望风险变化。 插值后的期望风险还取决于算法如何选解。图中曲线用于说明概念，不是实验数据， 也不表示所有网络都出现第二次下降。

# 038 深度学习的可学习性

fig:learning-spectral-product | 当前与提交前不同

提交前 · fbb26aec

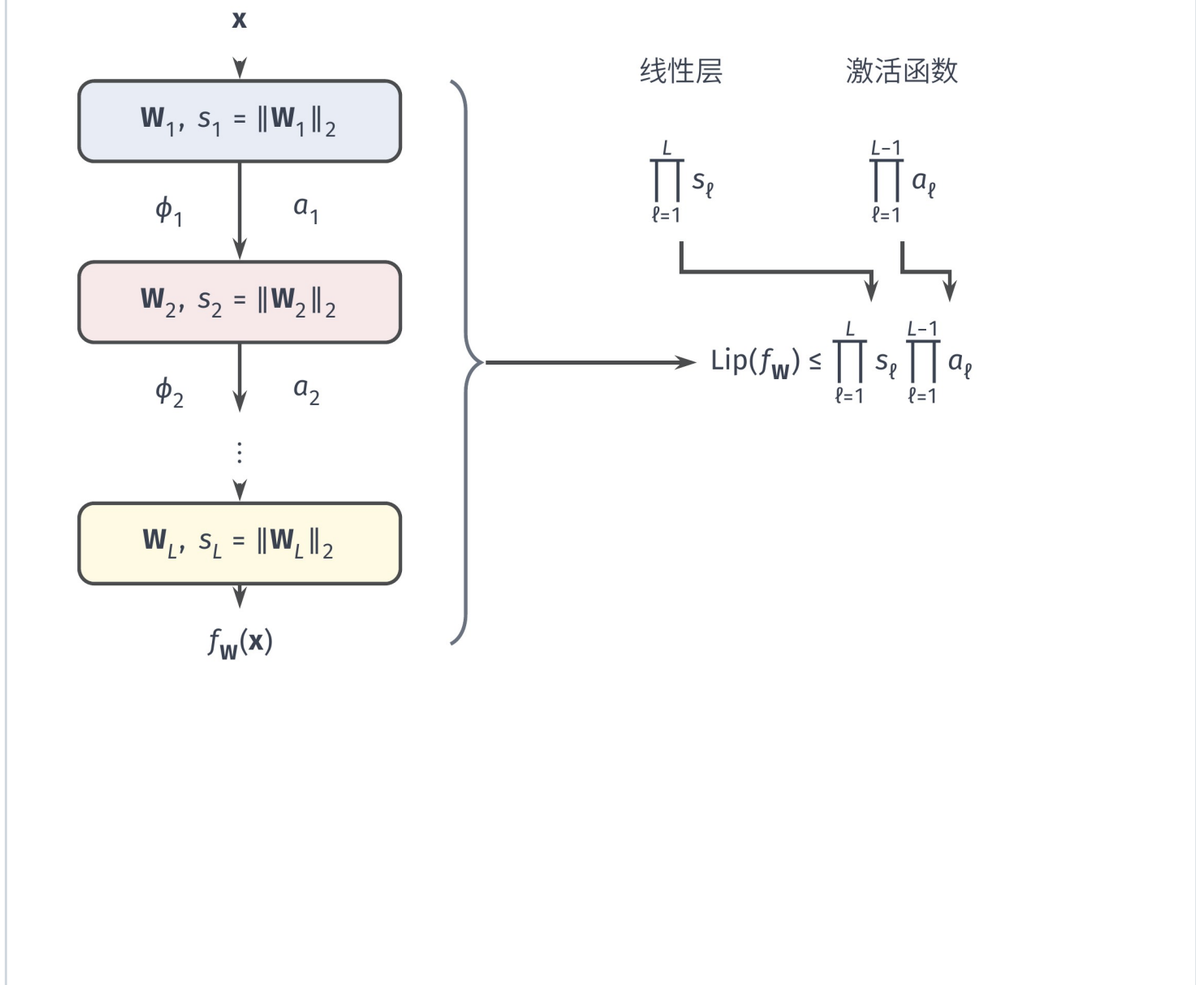


当前 · 7dd5e395

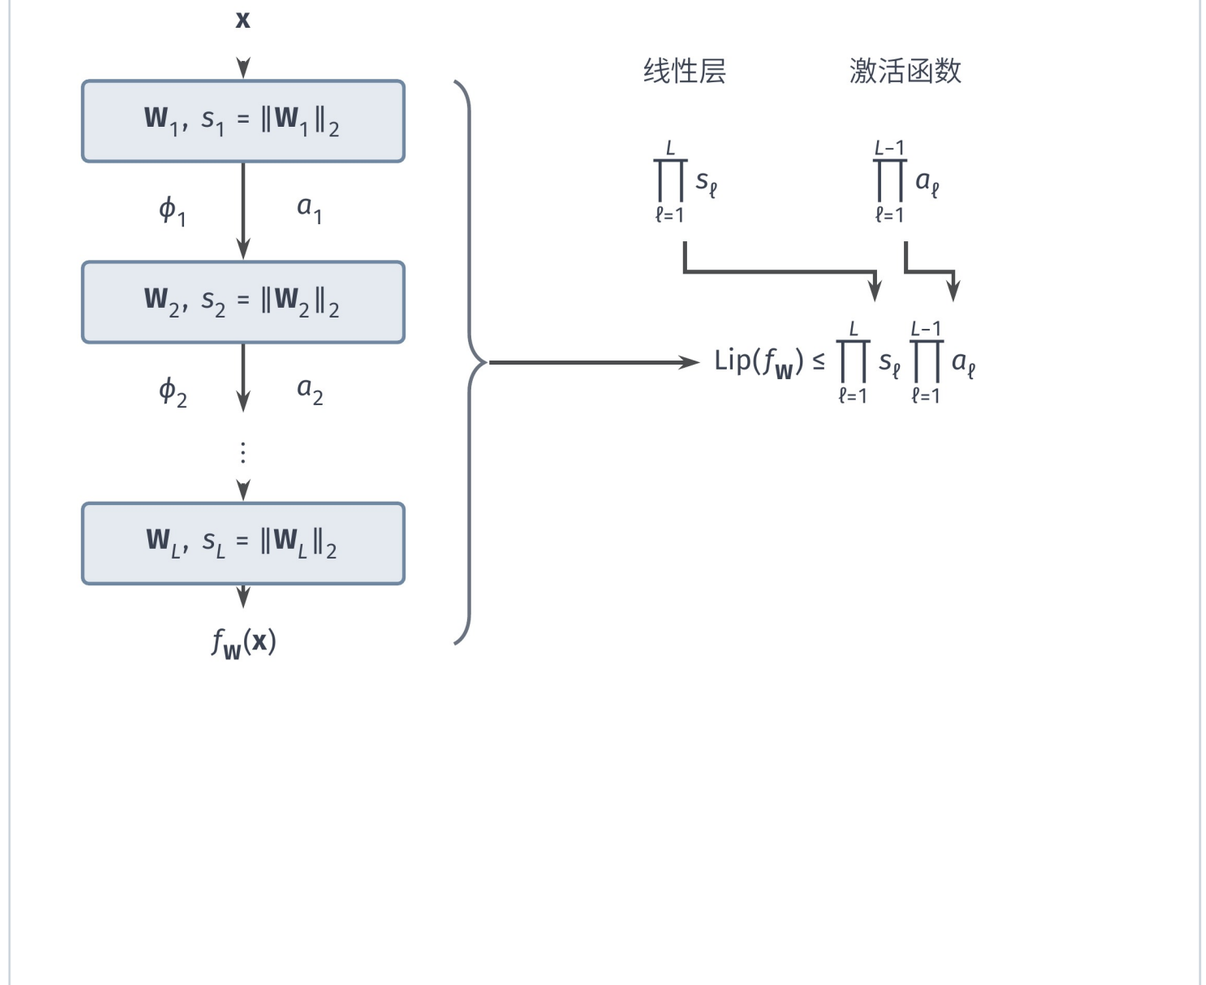


当前图注：谱范数与激活函数共同控制输入扰动。第层线性变换至多放大s_=\| W_\|_2倍，层间激活再至多放大a_倍；末层为线性输出。右上方两类因子分别连到乘积上界，大括号归并各层作用。当激活均为1-Lipschitz时，只剩谱范数乘积；该乘积仍不是完整的泛化复杂度。

# 039 深度学习的可学习性

fig:learning-ntk-linearization | 当前与提交前不同

提交前 · fbb26aec

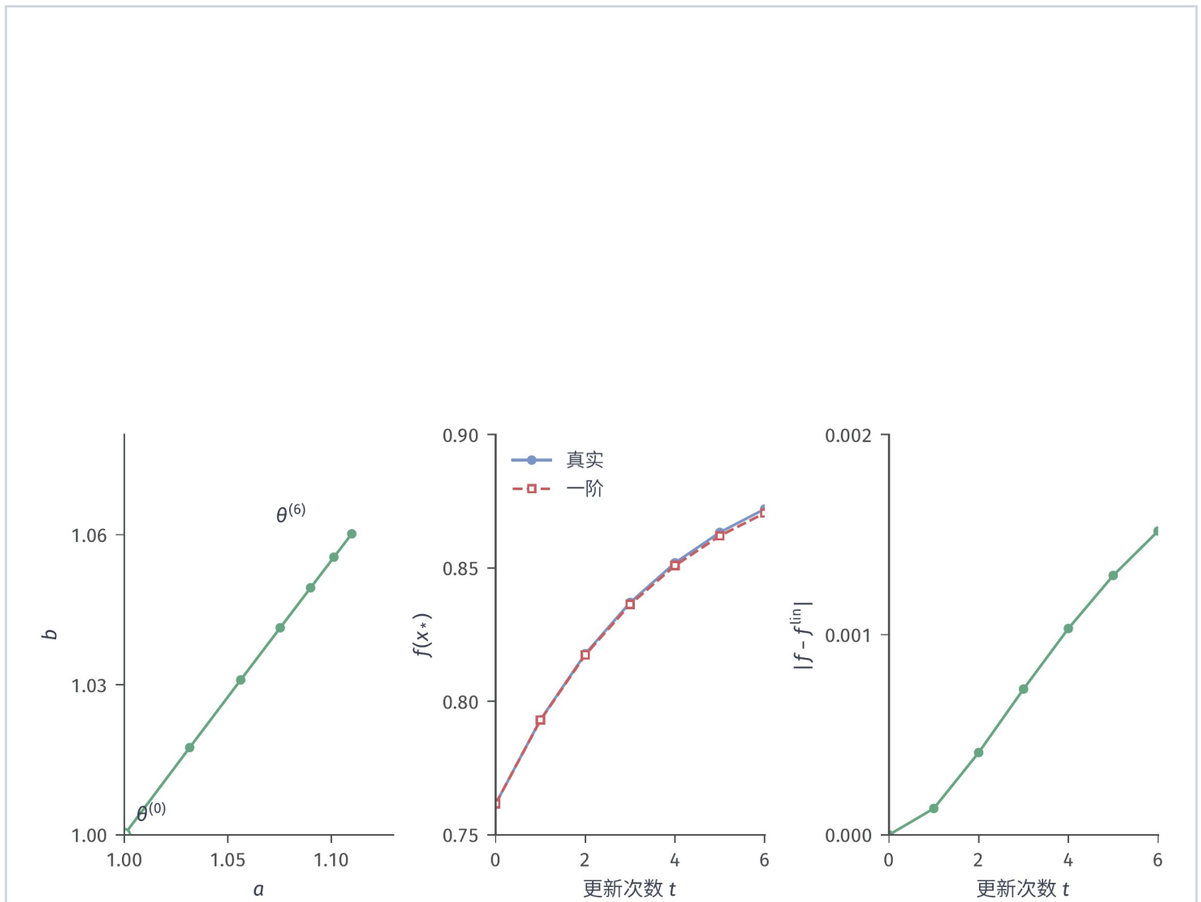


当前 · 7dd5e395

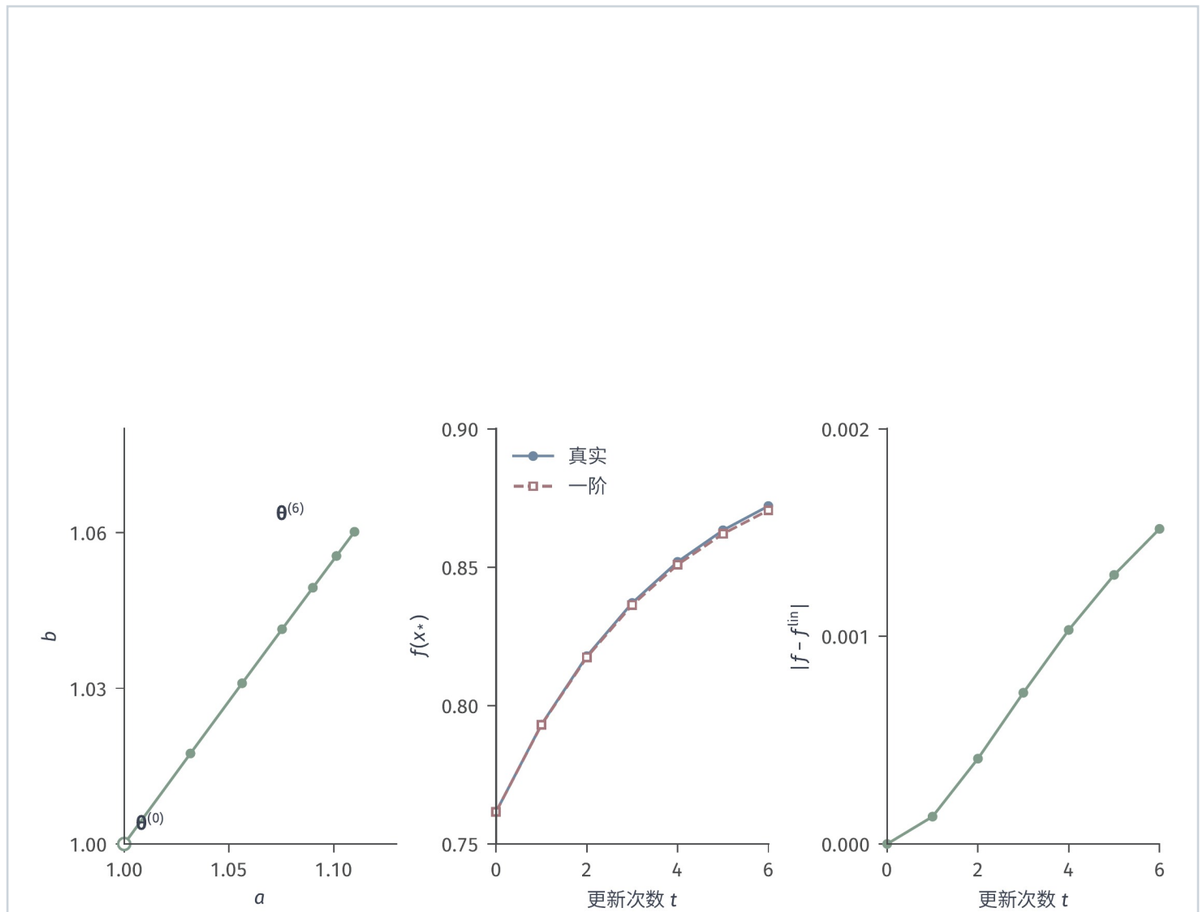


当前图注：初始化附近的参数轨迹与输出线性化。教学网络为f_(a,b)(x)=a(bx)， 初值为(1,1)^；用单个样本(x,y)=(1,0.9)的半平方损失、步长0.3执行六次 梯度下降，连同初值共七个检查点。中间的真实输出和一阶输出均在左侧同一参数轨迹 上计算；三面板绘图区大小相同，参数、输出和绝对余项各用所标坐标范围，不能按纸面高度直接比较数值。右侧余项末次约为0.00152。近初

# 040 深度学习的可学习性

fig:learning-ntk-features | 当前与提交前不同

提交前 · fbb26aec

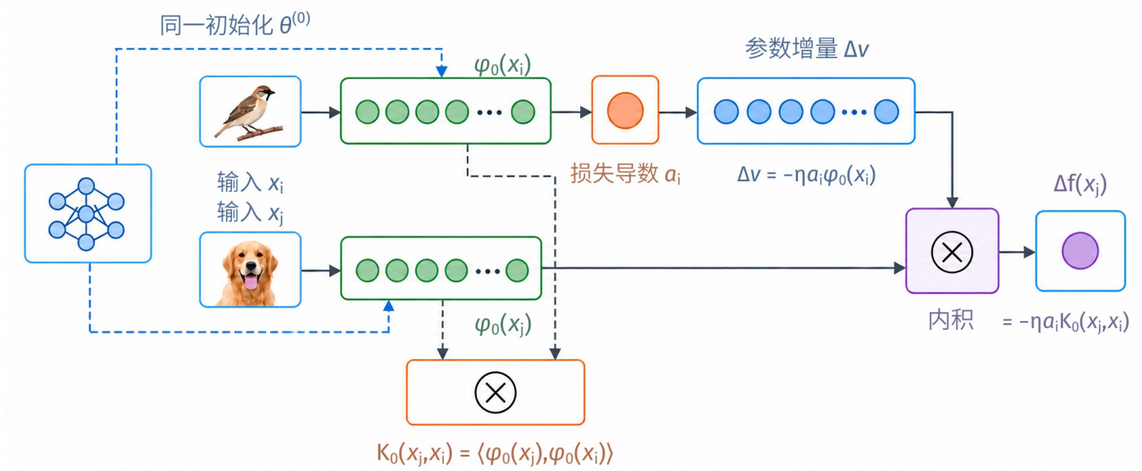


当前 · 7dd5e395

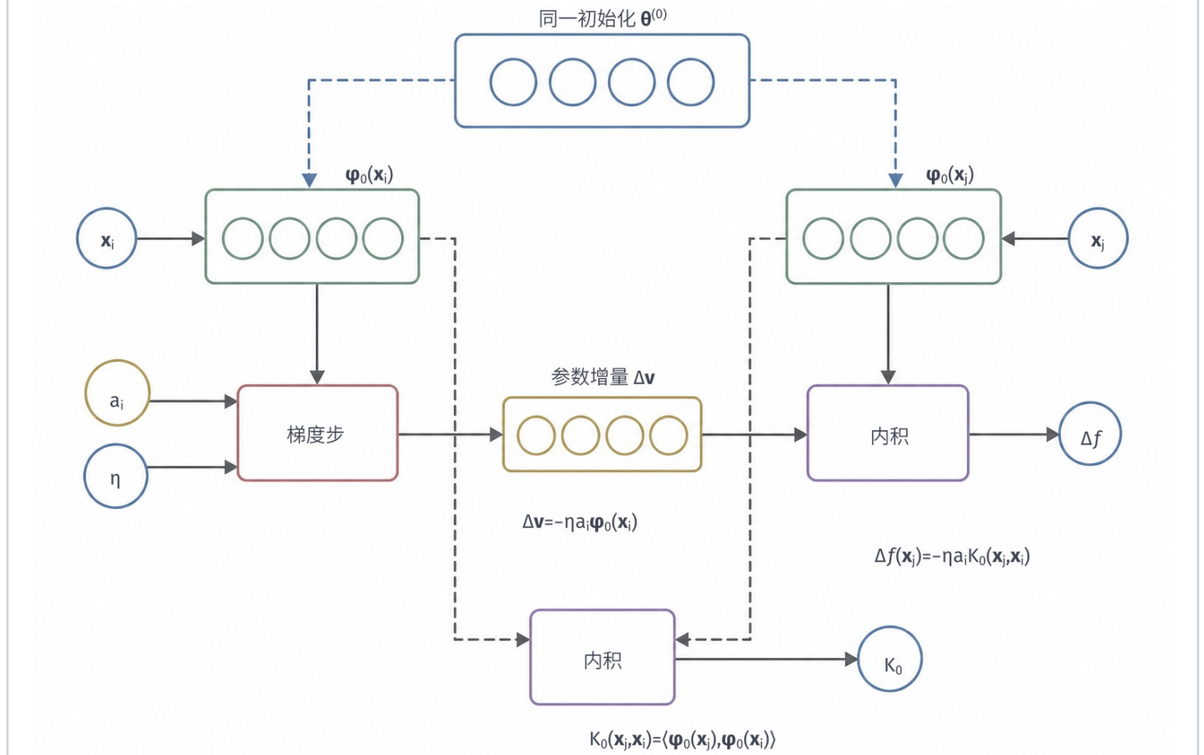


当前图注：初始梯度特征如何传递一次训练更新。在线性化模型中，样本i的梯度特征与损失对预测的导数a_i共同确定参数增量 v；将同一增量与样本j的梯度特征作内积，得到 f( x_j)。核值K_0正是两个初始梯度特征的内积。蓝色虚线把两份梯度关联到同一初始化，深色虚线展示核内积所用的两份梯度。特征条仅示意梯度坐标，不限定参数维数。对真实有限宽网络使用固定特征，还需控制核变化与线性化误差。

# 041 深度学习的可学习性

fig:learning-minimum-norm | 当前与提交前不同

提交前 · fbb26aec

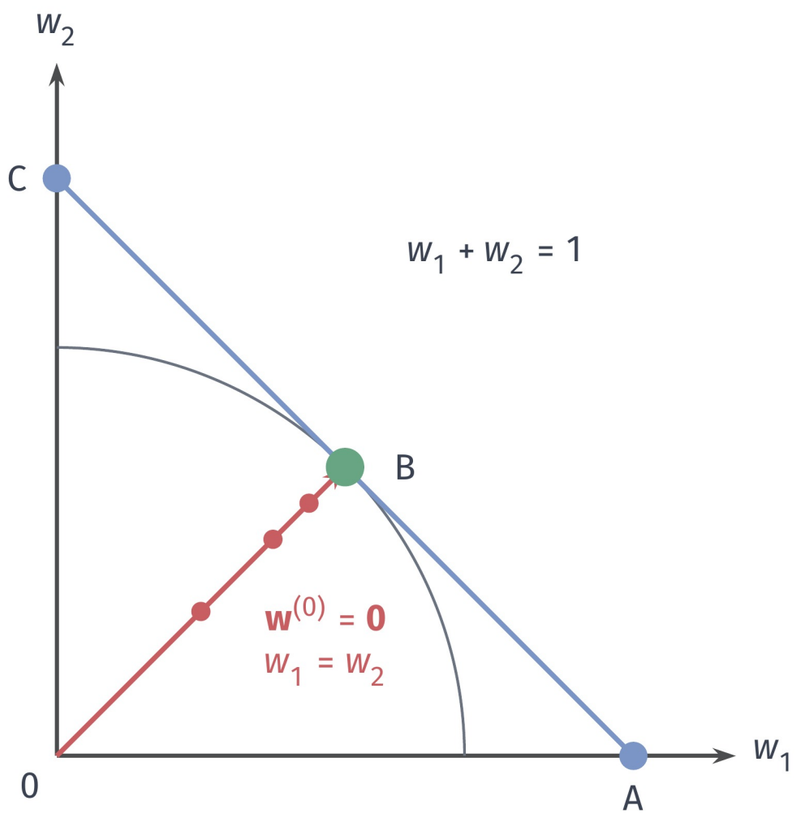


当前 · 7dd5e395

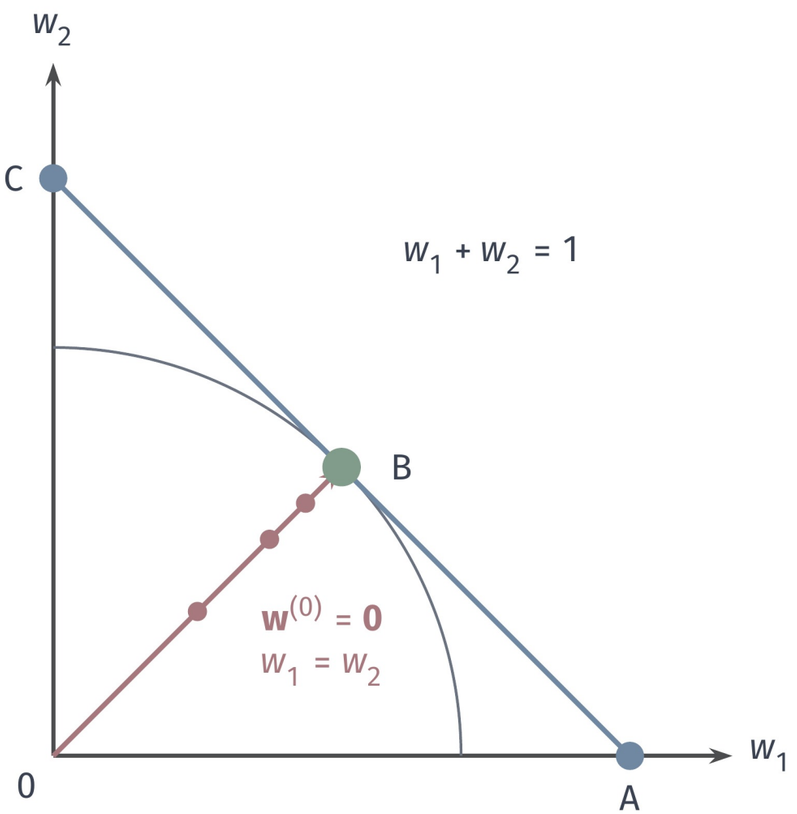


当前图注：一个训练观测对应多个插值参数。直线上的A、B、C都使输入(1,1)^的预测为1， 右侧列出它们对同一新输入 x_new=(1,0)^的预测。对半平方损失从零初始化，图中以步长1/4 画出前三次更新，轨迹趋向B；细弧表示经过B的欧氏范数等值线，说明B是插值直线上 距离原点最近的点。这个教学例子解释选解规则，不给出新输入的真实标签或泛化保证。

# 042 深度学习的可学习性

fig:parameter-distribution-semantics | 当前与提交前不同

## 提交前 · fbb26aec

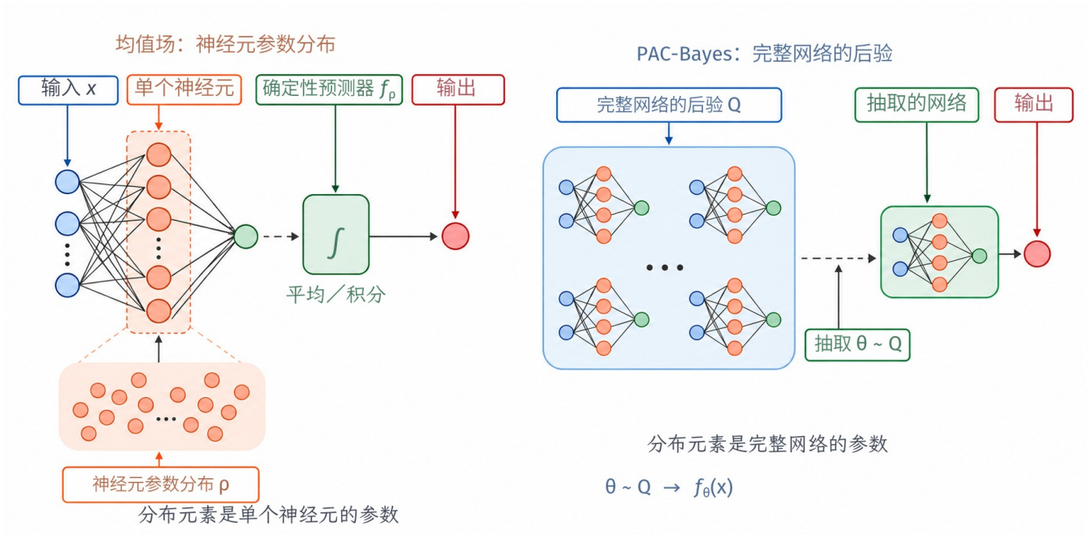


## 当前 · 7dd5e395

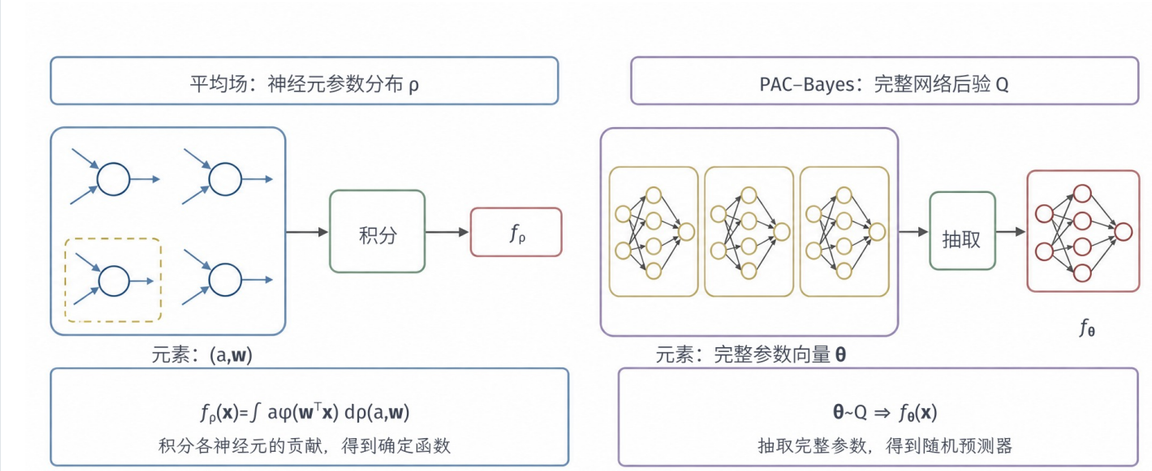


当前图注：两种分布的基本元素不同。平均场侧对单个神经元的贡献a( w^ x)积分，由神经元参数分布得到确定性预测器f_；网络、参数集合与积分表示同一预测器的不同表述，不是对完整网络的输出再做集成。PAC--Bayes侧的Q以完整参数向量为元素，抽取后才得到完整预测器f_。

# 043 深度学习的可学习性

fig:learning-flat-sharp | 当前与提交前不同

提交前 · fbb26aec

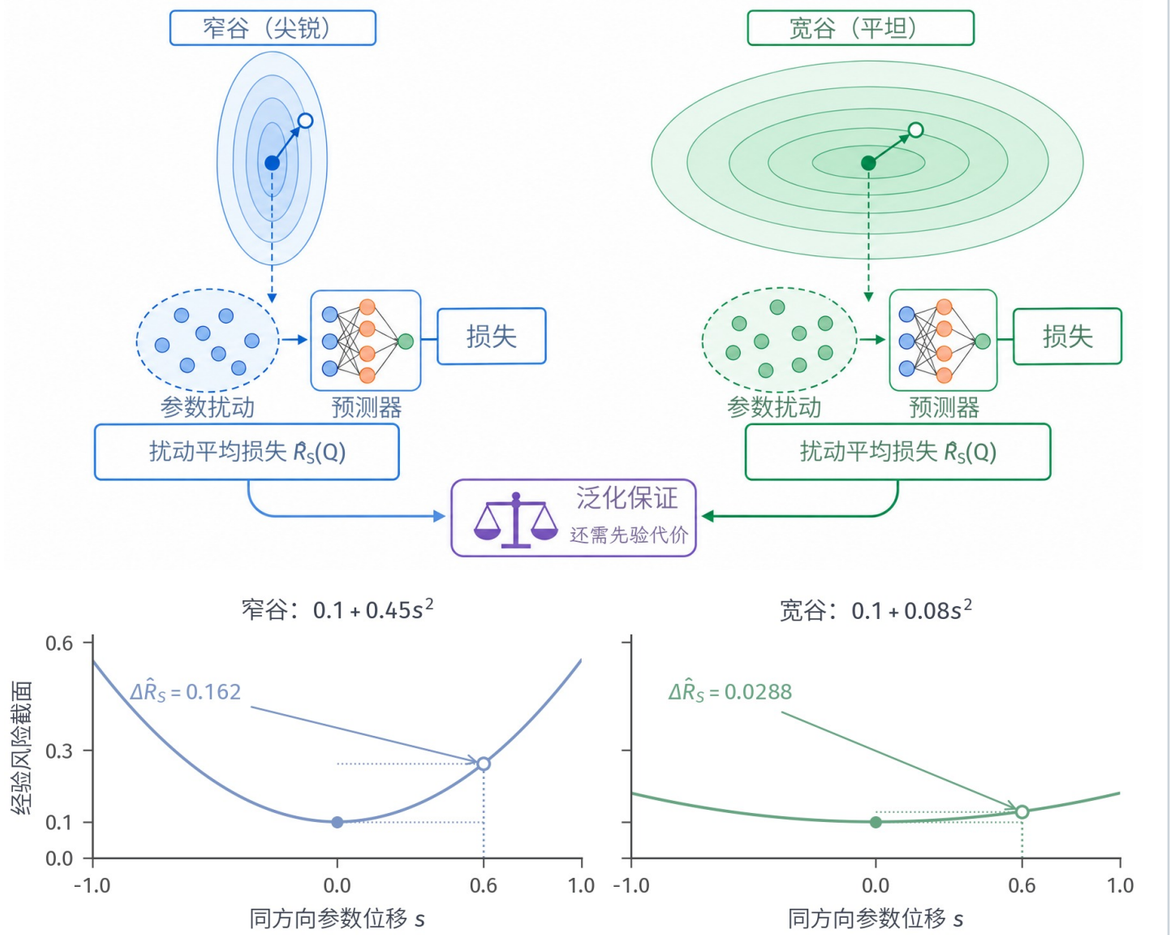


当前 · 7dd5e395

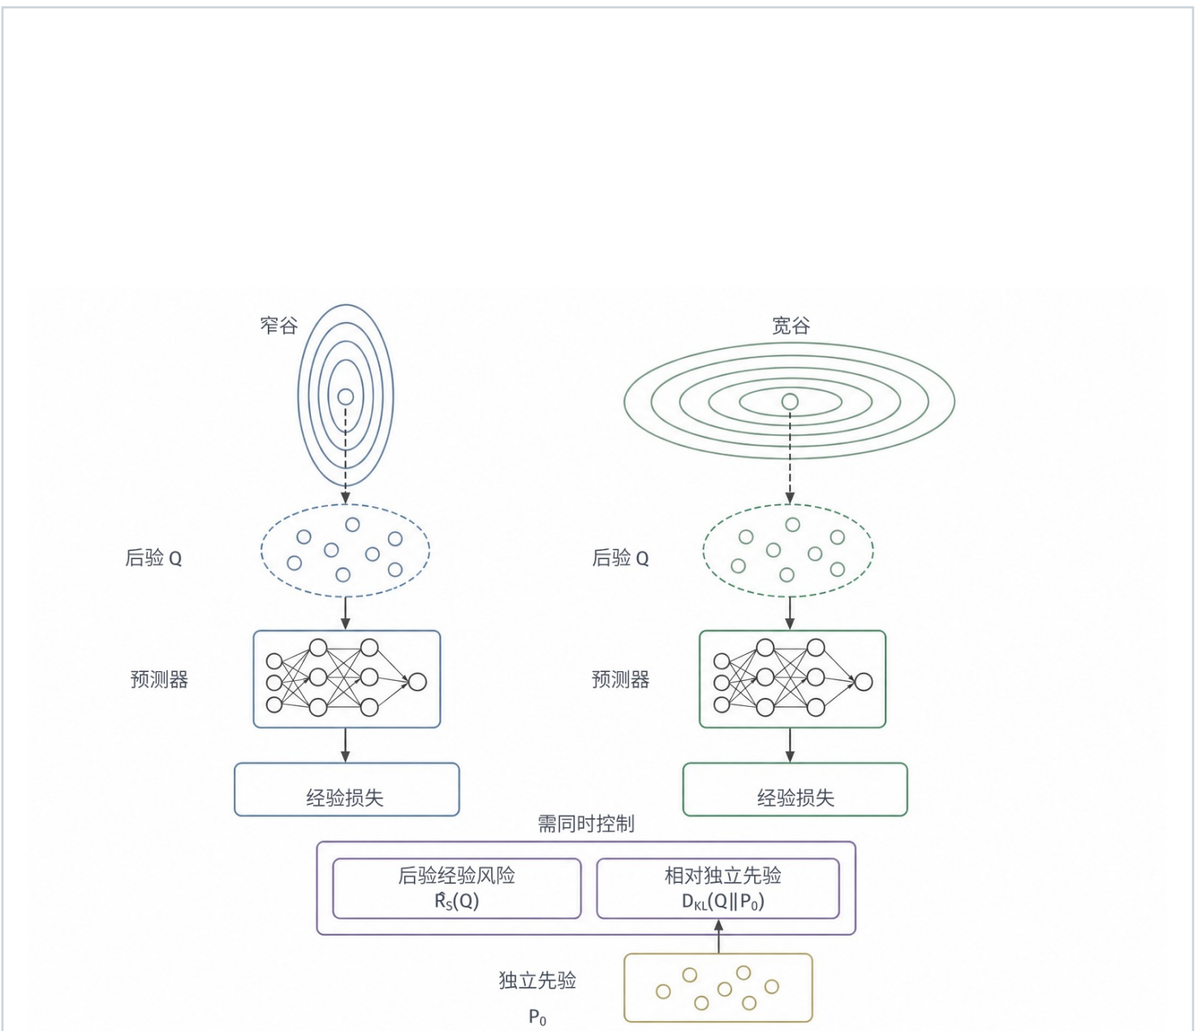


当前图注：参数扰动代价与PAC--Bayes中的两项控制。上部示意窄谷、宽谷附近的参数扰动与随机预测器；在相应定理条件下，泛化保证还需同时控制后验经验风险与相对于独立先验的相对熵代价。下部两个面板共用相同横纵尺度，横轴为同一单位方向上的参数位移s，即=+s u、\| u\|_2=1。构造的窄谷与宽谷分别为0.1+0.45s^2、0.1+0.08s^2；实心点为谷底，空心点对应相同位移s=

# 044 迁移学习的可学习性

fig:learning-distribution-shift | 当前与提交前不同

## 提交前 · fbb26aec

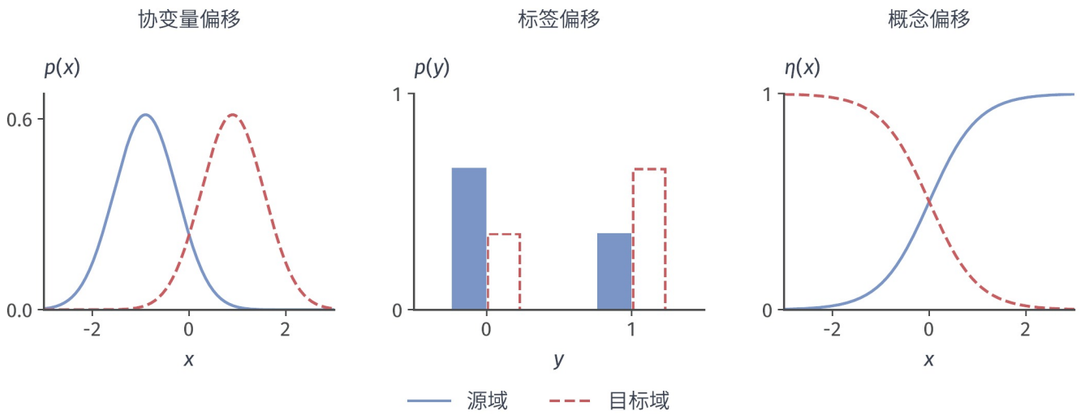


## 当前 · 7dd5e395

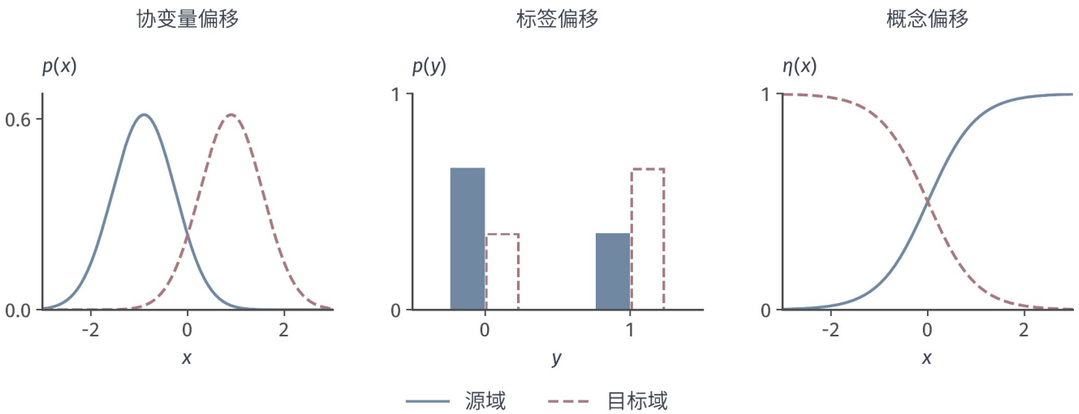


当前图注：分布偏移改变联合分布的不同组成部分。实线表示源域，虚线表示目标域；密度、类别比例和条件概率均为规范化的教学构造，不表示实测频率。协变量偏移允许输入分布改变，标签偏移允许类别比例改变，概念偏移则改变给定输入后的标签分布，图中(x)= P(y=1 x)。这些设定还需与覆盖条件或其他可识别条件结合，才能支持迁移保证。

# 045 迁移学习的可学习性

fig:learning-support-coverage | 当前与提交前不同

## 提交前 · fbb26aec

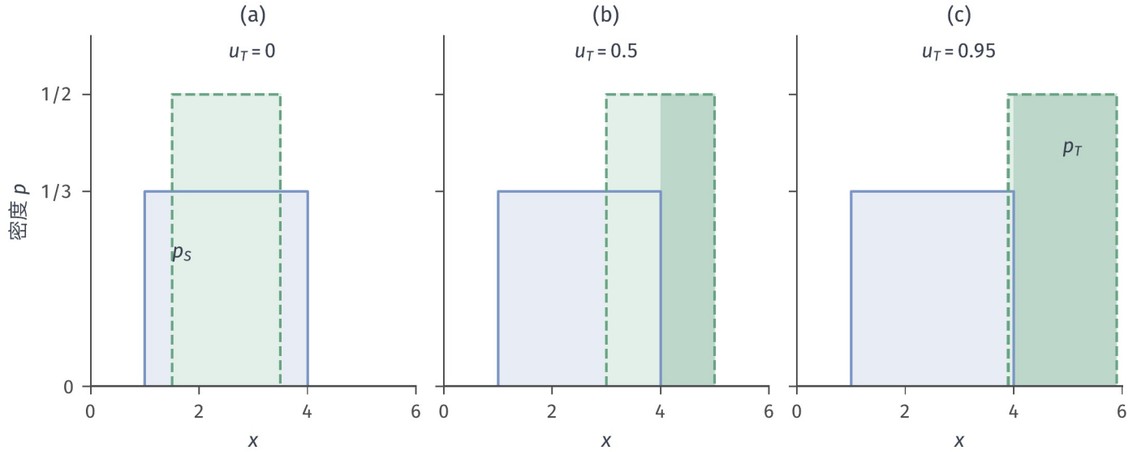


## 当前 · 7dd5e395

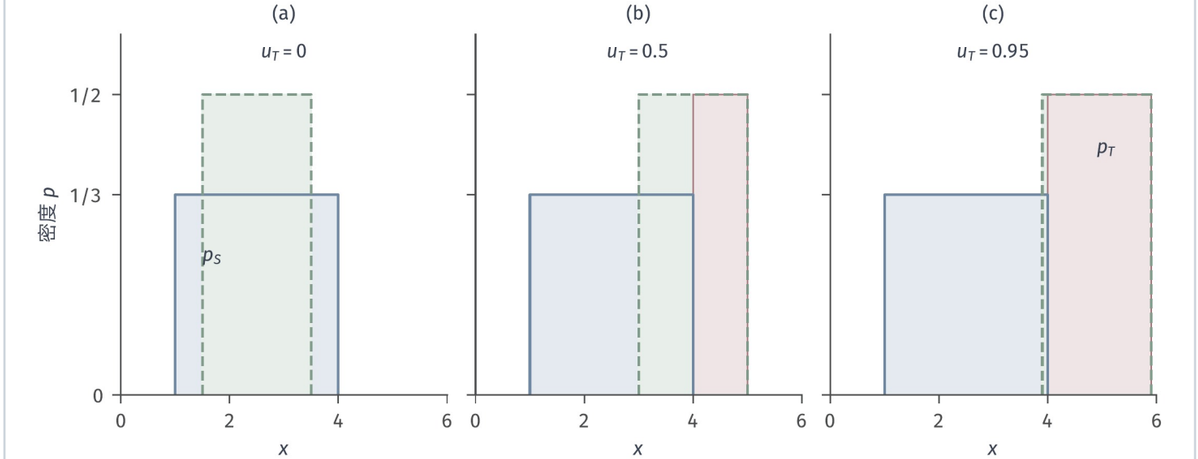


当前图注：同尺度的三种支持覆盖。源密度均为[1,4]上的1/3，目标密度均为长度2区间上的1/2；(a)、(b)、(c)的目标支持依次为[1.5,3.5]、[3,5]、[3.9,5.9]。深色区域没有源密度，其目标概率u_T= P_T\p_S(X)=0\依次为0、0.5、0.95。实线、虚线与底色共同区分源域、目标域；只有(a)满足覆盖条件p_T(x)>0 p_S(x)>0。密度为规范化

图片保持原比例；同框适配，仅用于比较独立图。完整图注与源路径见网页及清单。

# 046 迁移学习的可学习性

fig:learning-alignment-counterexample | 当前与提交前不同

## 提交前 · fbb26aec

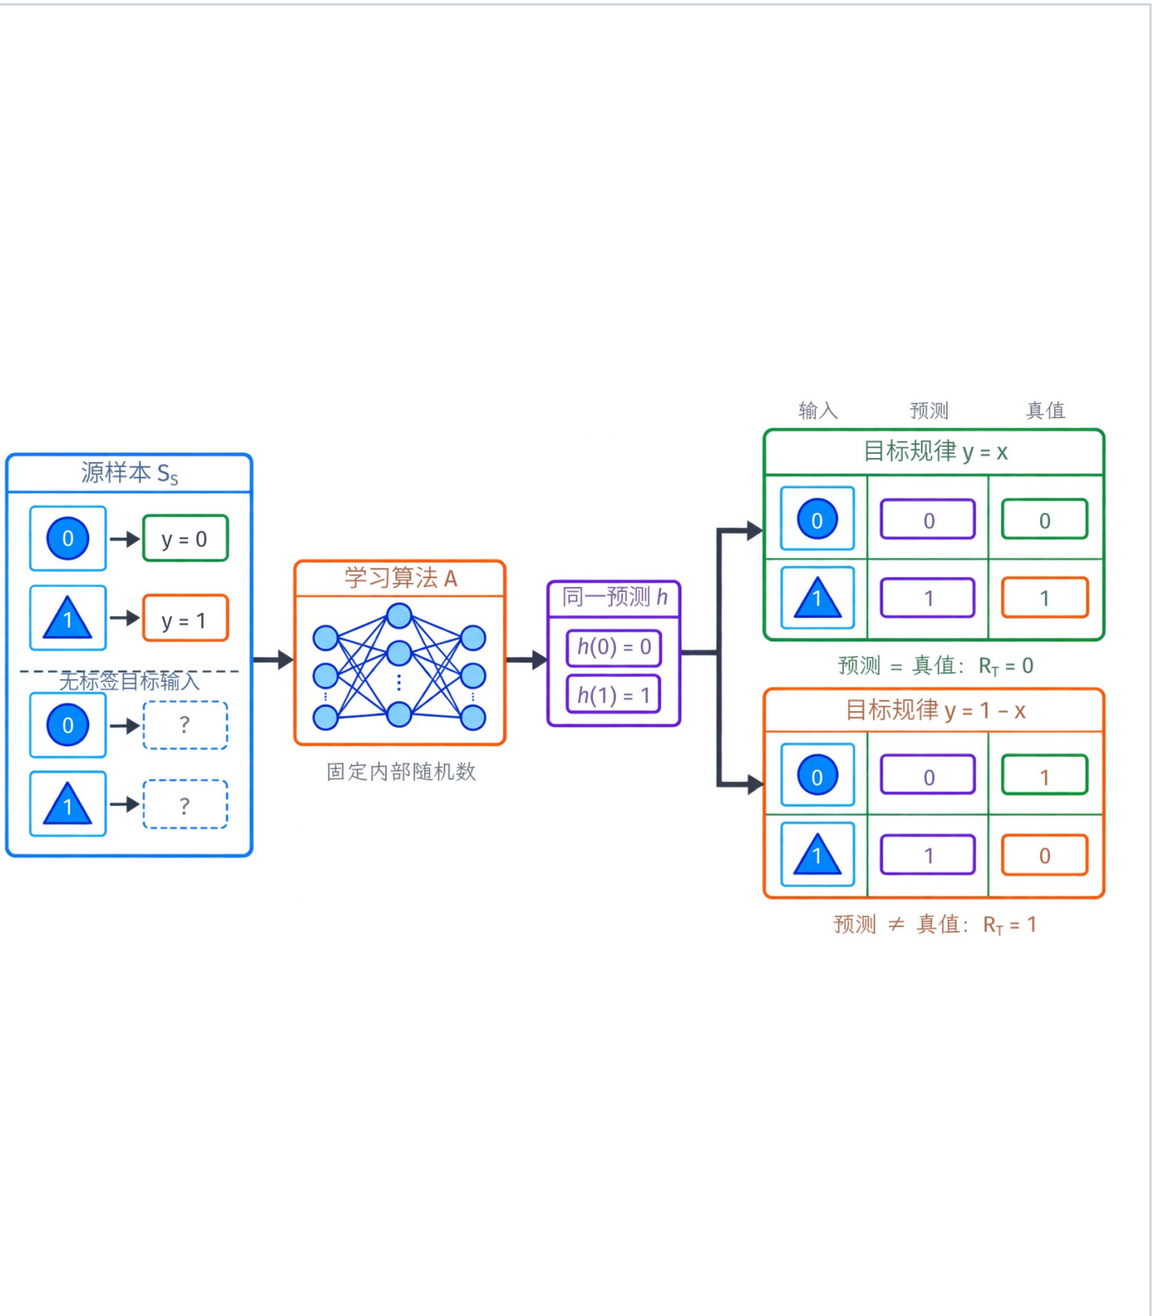


## 当前 · 7dd5e395

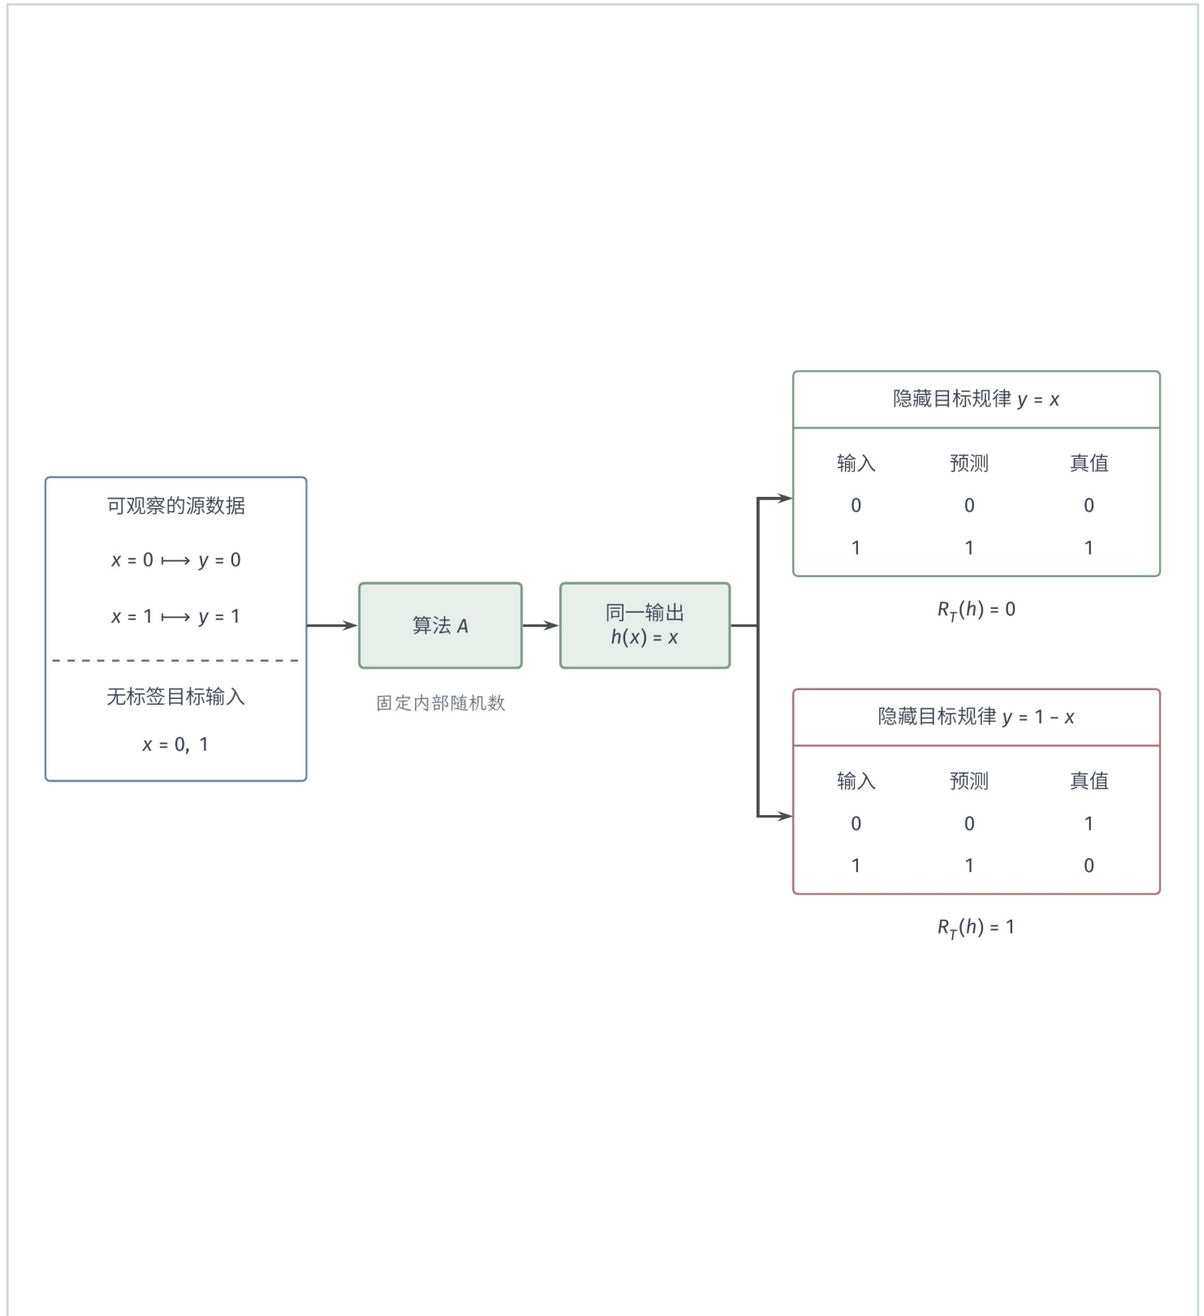


当前图注：相同可观察数据不能区分两种目标规律。两域都以概率1/2产生输入0或1，源标签为y=x。算法只收到左侧带标签源样本和无标签目标输入，目标标签并未提供；右侧两种可能分别取y=x与y=1-x。固定算法内部随机数后，两种情形必得到同一输出。图中以h(x)=x为例，两张表逐点对照同一预测与隐藏标签：零一损失下，源风险为0，两种目标风险分别为0、1。任意二分类输出在这两种目标规律下的风险之

# 047 迁移学习的可学习性

fig:learning-domain-classifier | 当前与提交前不同

提交前 · fbb26aec

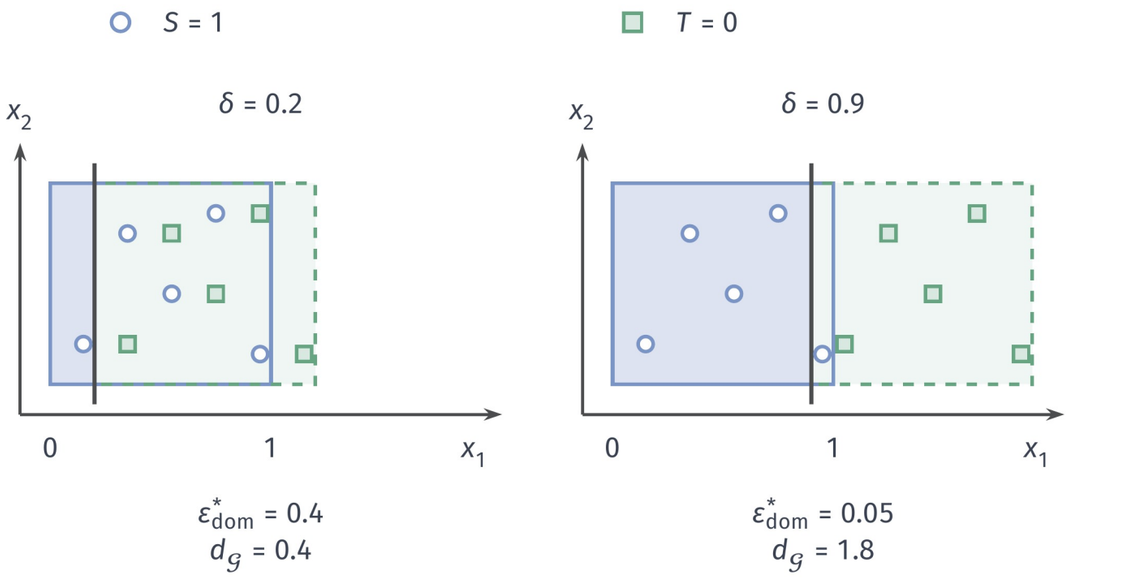


当前 · 7dd5e395

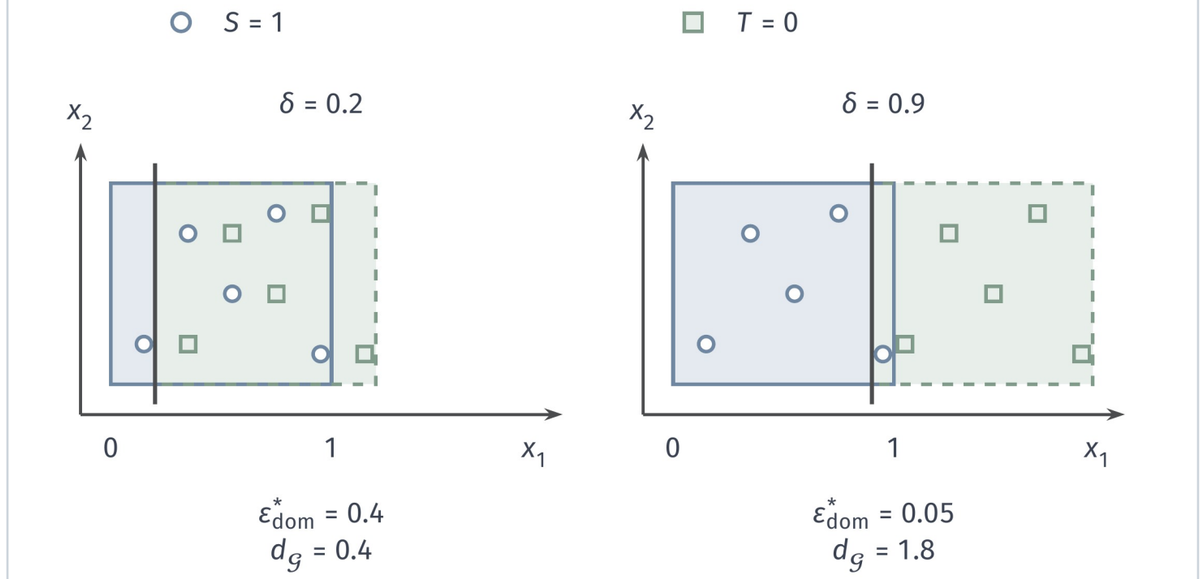


当前图注：域分类器的错误只对应输入散度项。源输入均匀分布于[0,1]^2，目标输入均匀分布于[,1+][0,1]，其中01；圆点、方块的位置为教学构造，错误率由区域概率计算。 H含双向阈值与常值假设，域分类器类取 G= H H。其中g=h_0 h_在左侧浅色带预测源域，h_a(x)= I\x_1 a\；两域均等先验时，最小域错误为(1-)/2，d_ G=2。任务风险界还包含源风险及=_h

# 048 迁移学习的可学习性

fig:learning-importance-weighting | 当前与提交前不同

提交前 · fbb26aec

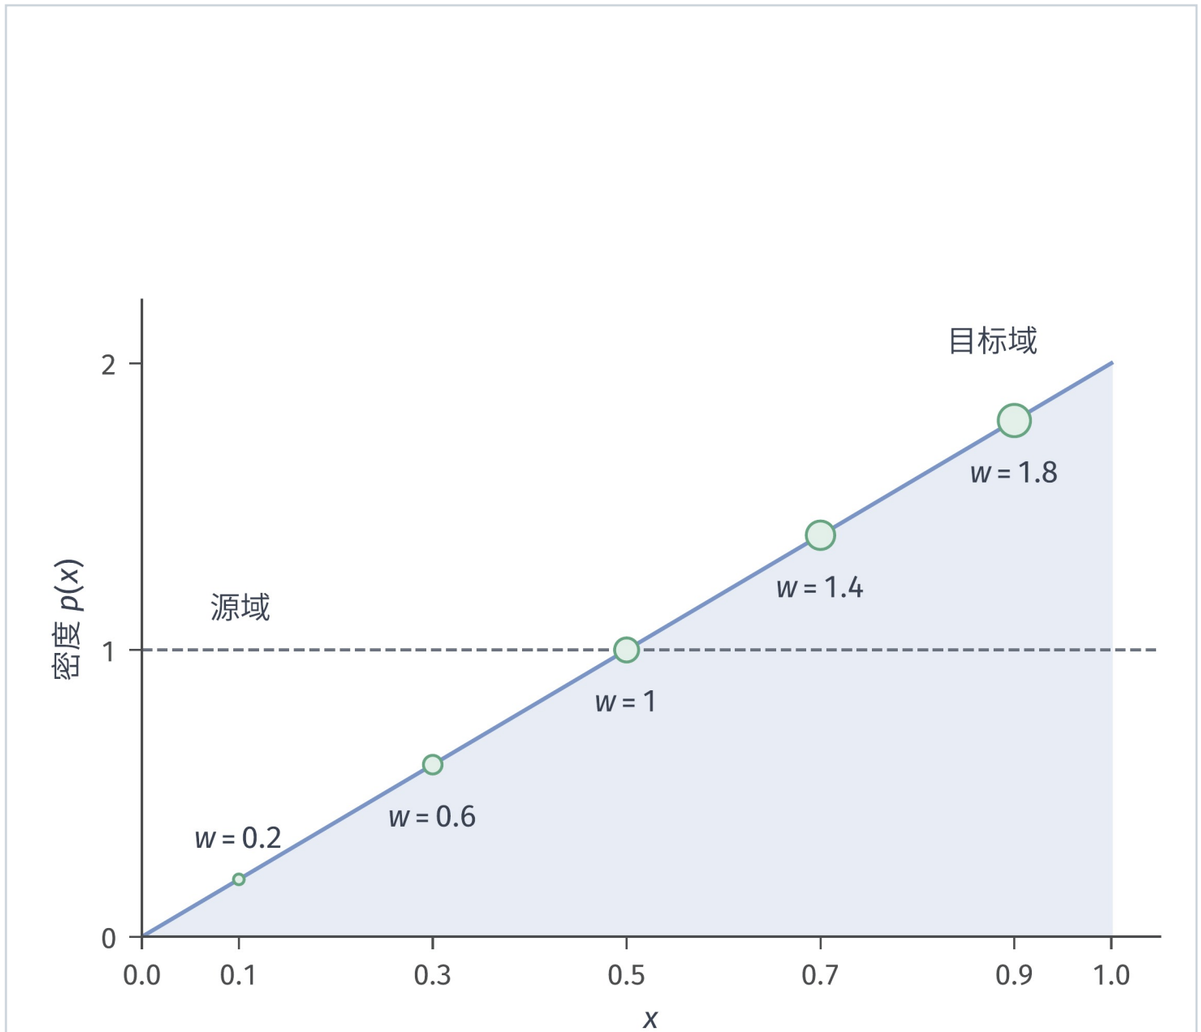


当前 · 7dd5e395

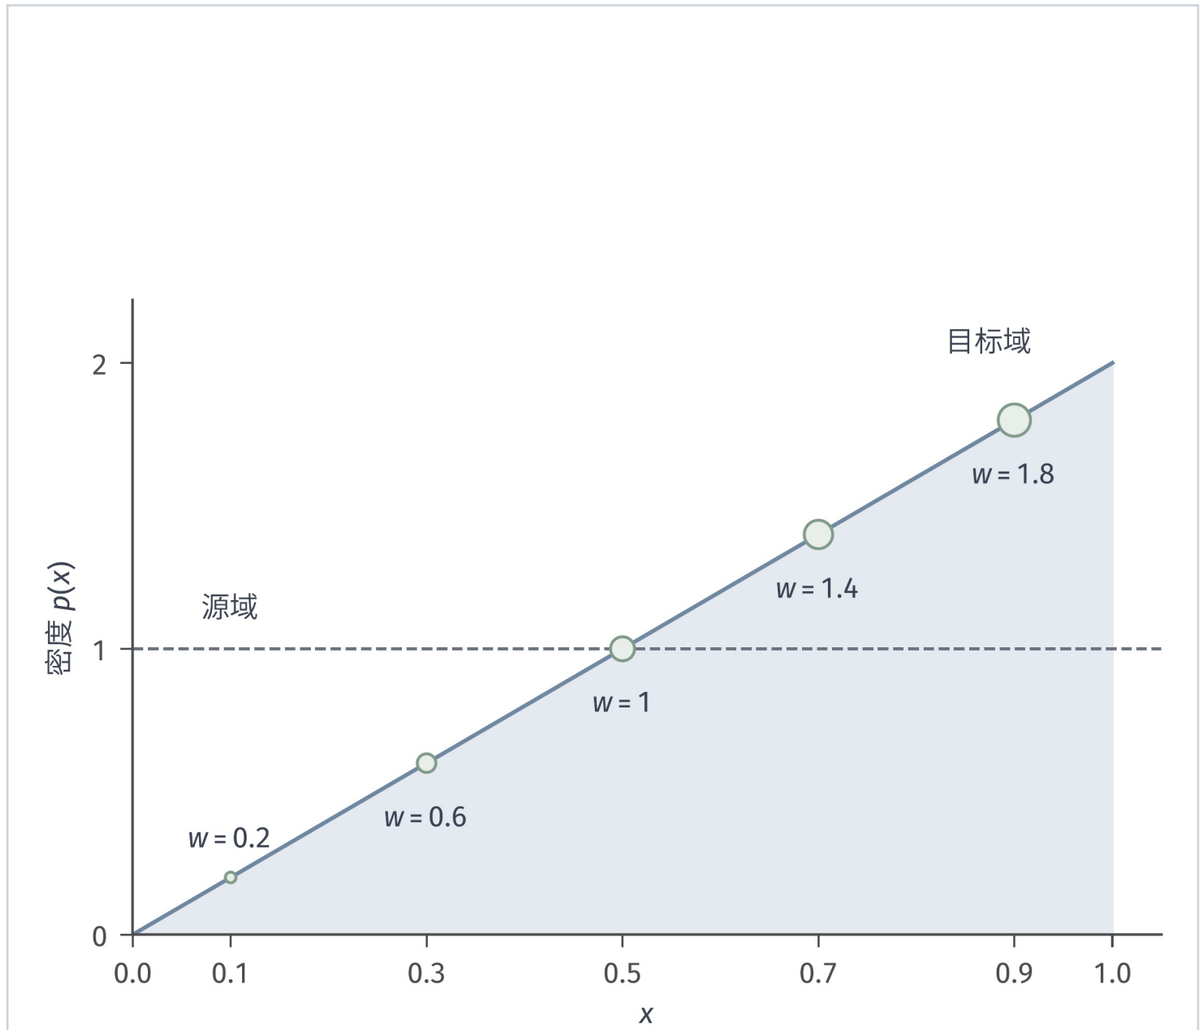


当前图注：重要性权重重新分配源样本的贡献。在[0,1]上构造源密度p_S(x)=1、 目标密度p_T(x)=2x，二者均积分为1，因此w(x)=2x。 五个源样本位置人为取为0.1、0.3、0.5、0.7、0.9，权重依次为0.2、0.6、1、1.4、1.8。 圆点叠在目标密度上，面积与权重成正比，面积不表示局部样本数量。 目标输入必须受到源输入覆盖；要使用风险恒等式，还需保持相同的条件

# 049 迁移学习的可学习性

fig:learning-environment-sampling | 当前与提交前不同

## 提交前 · fbb26aec

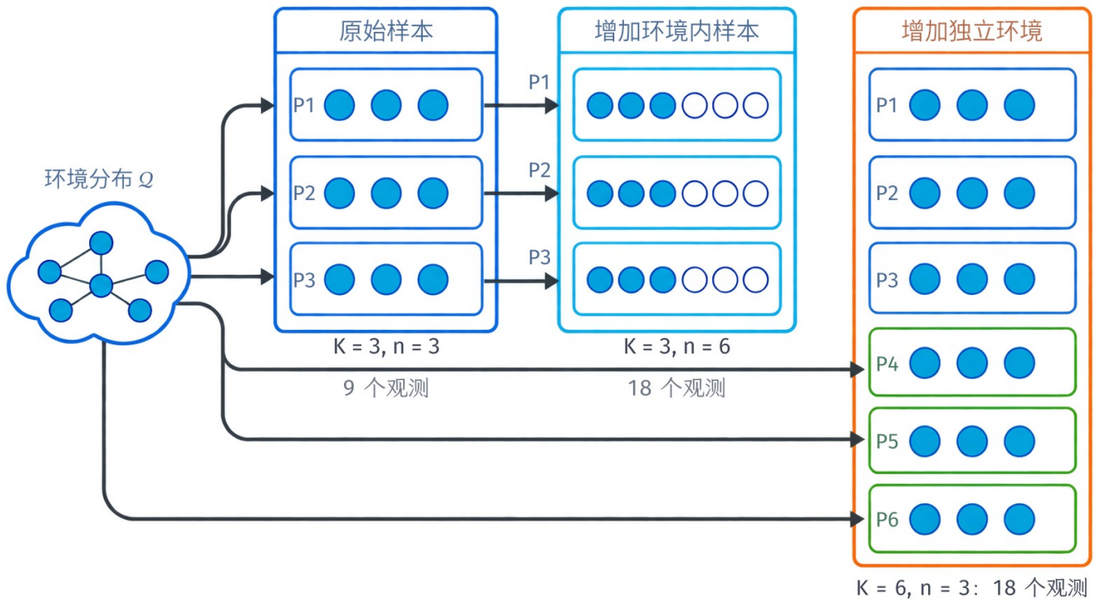


## 当前 · 7dd5e395

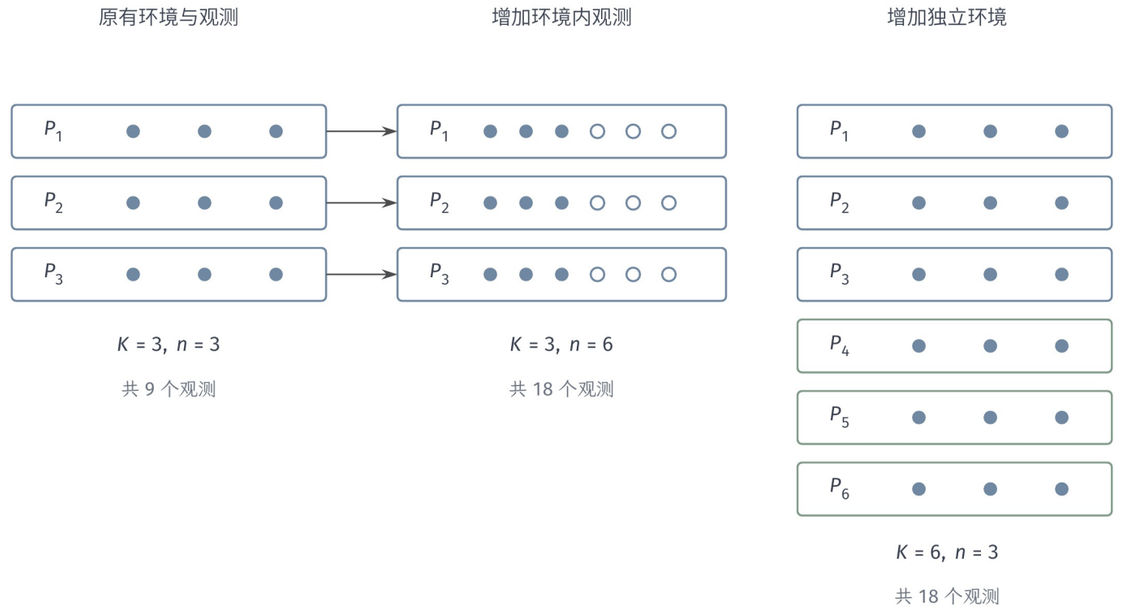


当前图注：环境数量K与环境内样本数n对应不同的抽样层。每行边界代表一个环境， 圆点代表其中的观测。左侧从同一环境分布 Q独立抽取3个环境，各取3个观测； 中间的空心点表示在原有3个环境中继续抽取的观测，每个环境增至6个；右侧从 Q 新抽取3个独立环境，每个环境仍取3个观测。 中、右都有18个观测，只有右侧增加了独立环境数量。图中数量为教学构造，不对应实测数据。

图片保持原比例；同框适配，仅用于比较独立图。完整图注与源路径见网页及清单。

# 050　可信机器学习基础

fig:trust-technical-scope | 当前与提交前不同

提交前 · fbb26aec

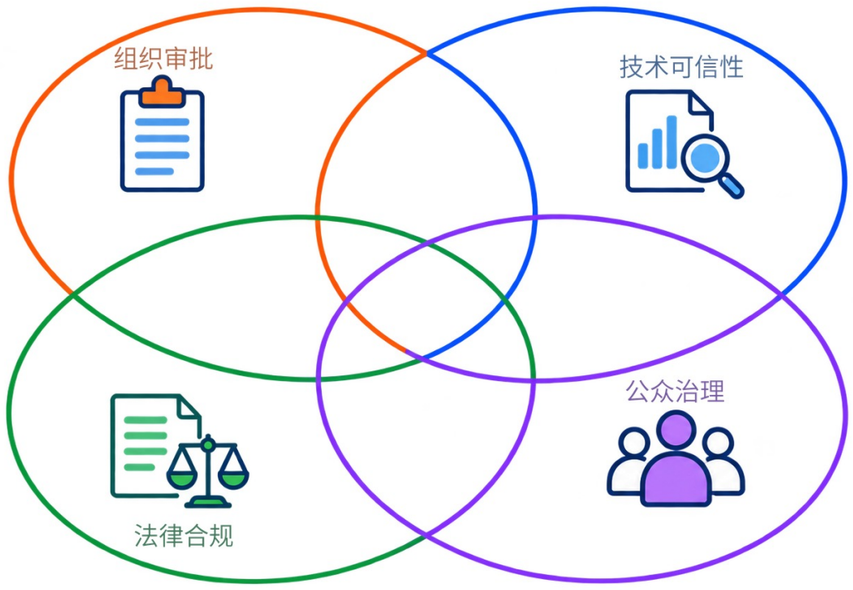


当前 · 7dd5e395

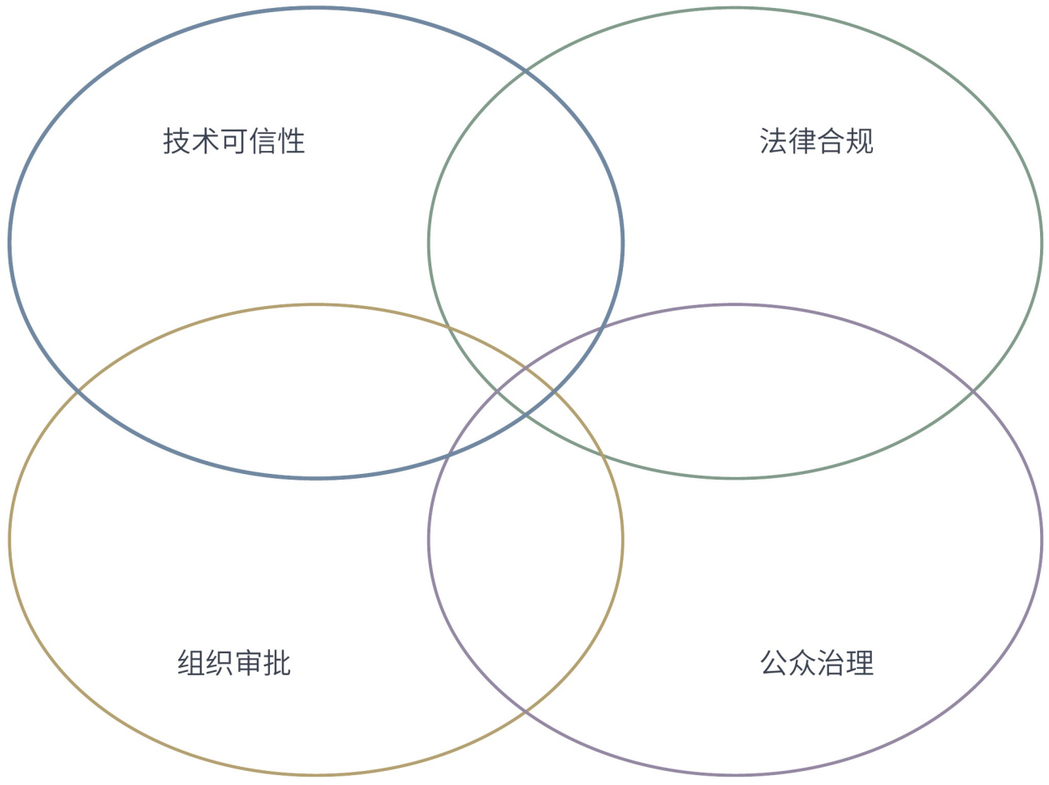


当前图注：蓝色轮廓标出本书讨论的技术证据，其他区域表示法律合规、组织审批与公共治理。交叉处只示意共享议题；边界及面积不表示集合度量、逻辑包含或责任继承，各主体仍依自身要求判断。

# 051　可信机器学习基础

fig:trust-three-layers | 当前与提交前不同

## 提交前 · fbb26aec

## 当前 · 7dd5e395

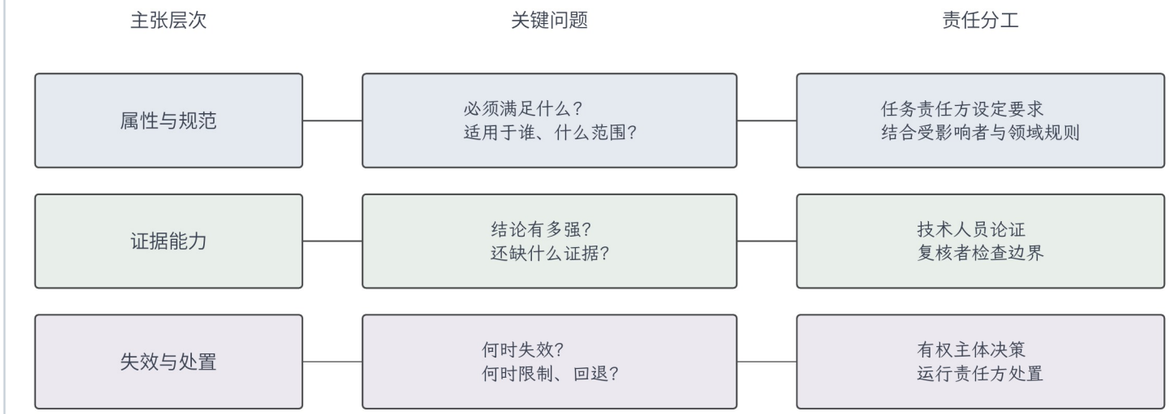


当前图注：要求、证据及失效处置构成可信主张的三个层次。系统属性选择考察维度，规范要求确定条件；证据限定结论强度；生命周期条件确定暂停沿用和响应。三行分别连接任务方的要求、技术论证与独立复核、有权主体的风险决定和运行方处置。横线只表示同层对应，教学分工仍需由真实授权与审批落实。

# 052 可信机器学习基础

fig:trust-decision-consequences | 当前与提交前不同

## 提交前 · fbb26aec

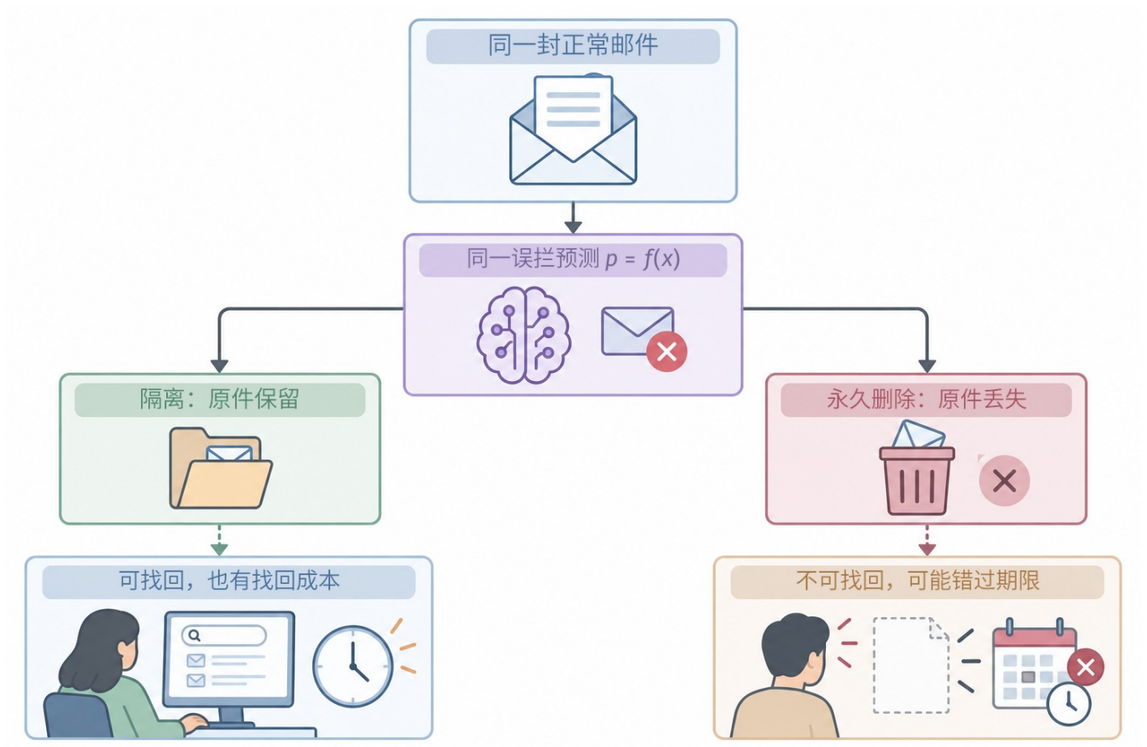


## 当前 · 7dd5e395

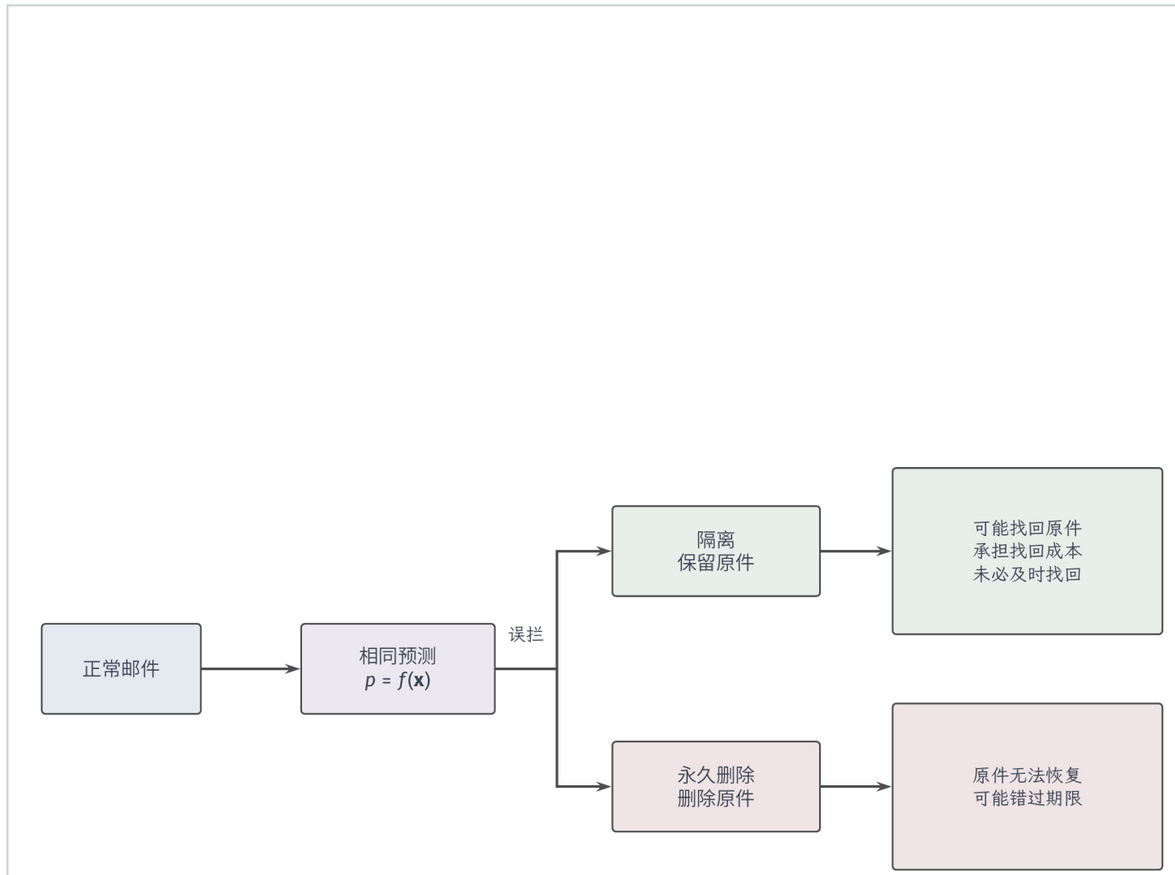


当前图注：保持p=f( x)不变，比较同一正常邮件误拦后的隔离与永久删除。左侧保留原件可供找回，右侧删除原件；末端收件人可能承担找回成本或错过期限。L(a,y)还需计入真实状态y、发现延误和恢复成本。情景为构造，保留原件并不保证及时找回。

# 053 可信机器学习基础

fig:trust-research-problems-map | 当前与提交前不同

## 提交前 · fbb26aec

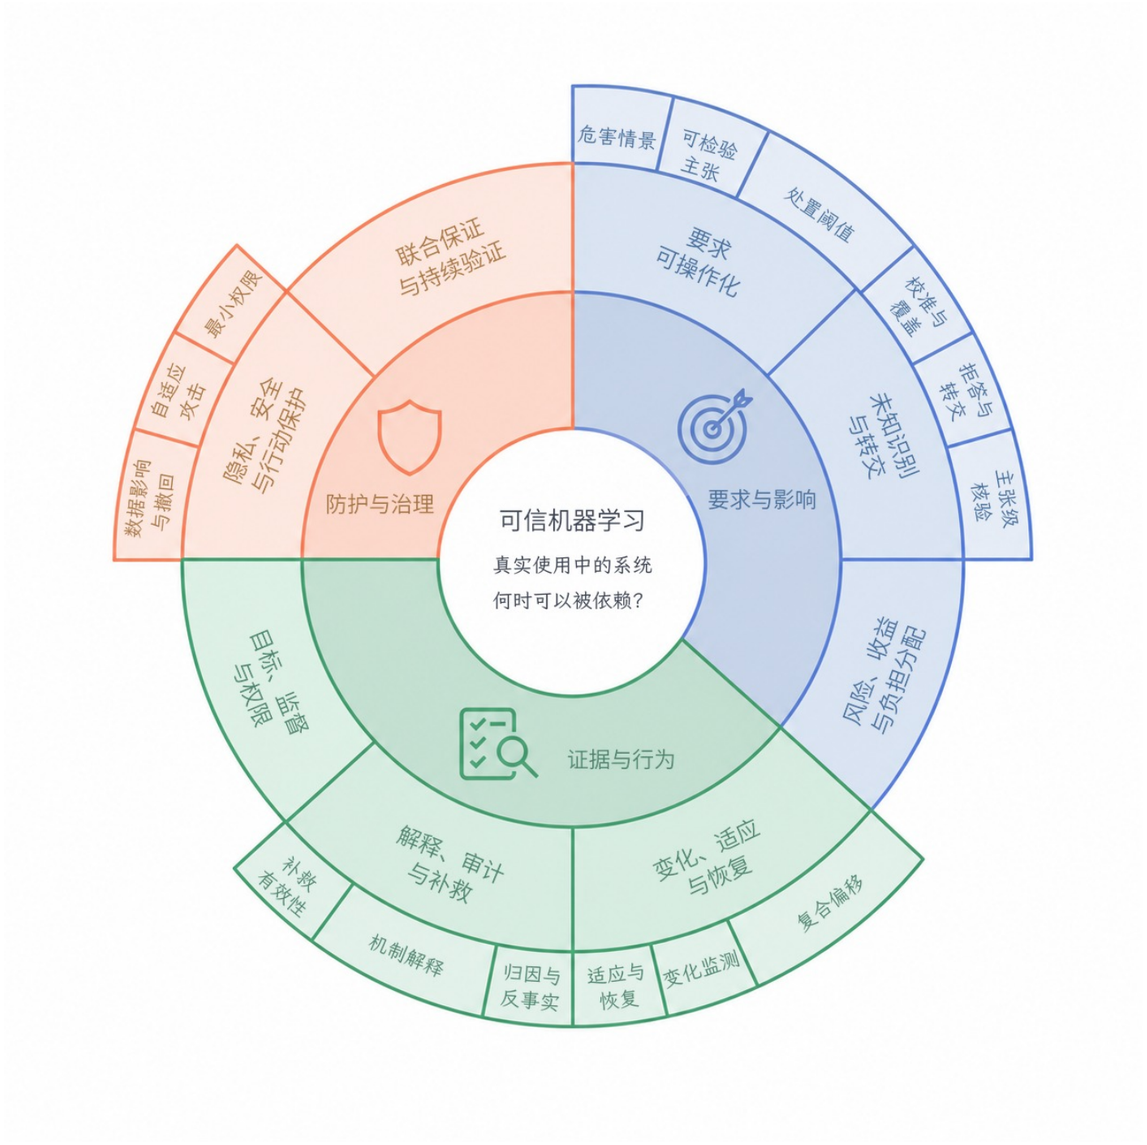


## 当前 · 7dd5e395

当前图注：研究地图由使用问题向下展开：三组判断领域连接八项问题，其中五项列出危害情境、覆盖、复合偏移、机制解释、自适应攻击等十五项课题。连接线表示领域、问题和课题的组织层次，排列不表示因果或先后顺序。其余三个问题仅是未列示例。

# 054 可靠性

fig:trust-reliability-review | 当前与提交前不同

提交前 · fbb26aec

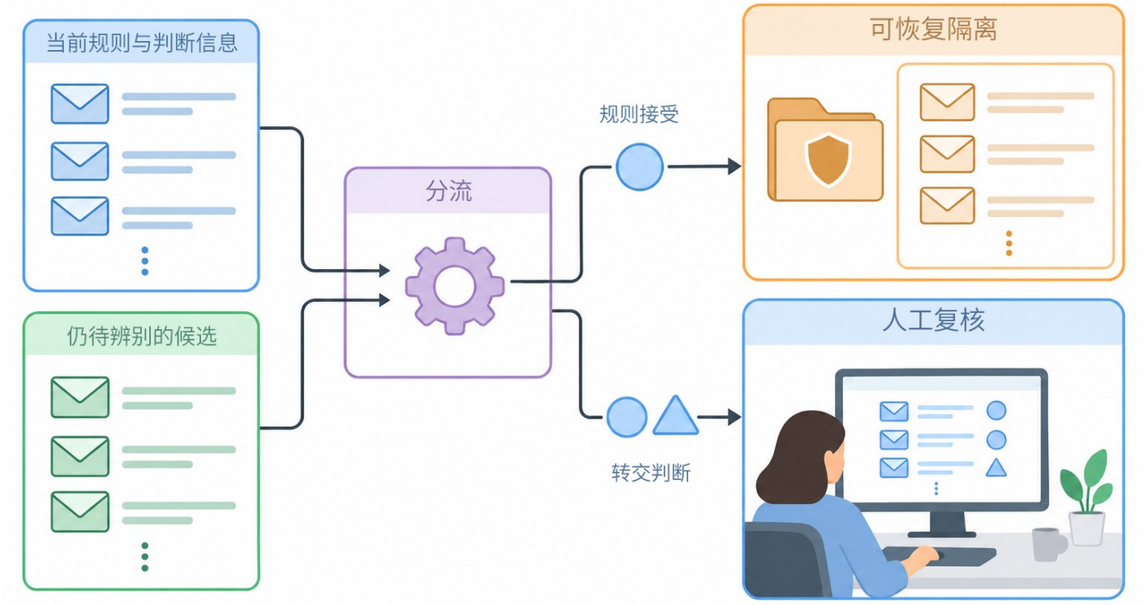


当前 · 7dd5e395

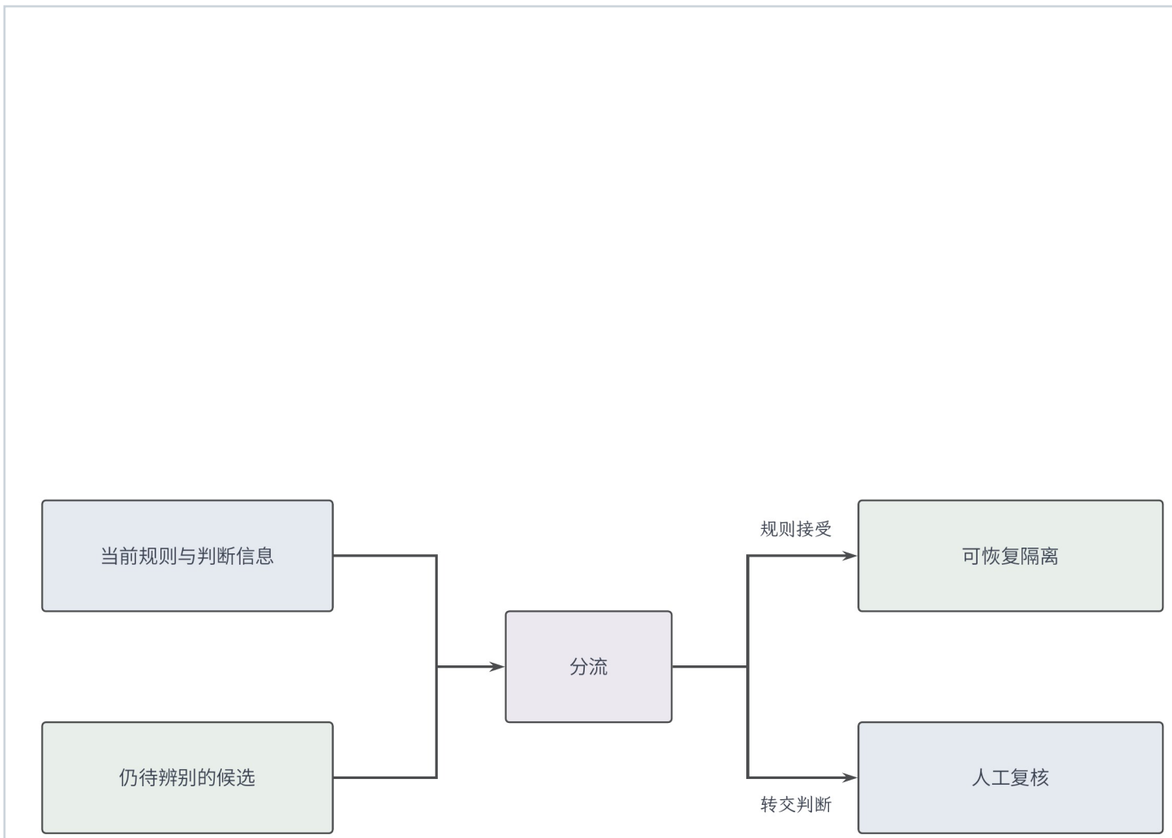


当前图注：邮件按当前规则的判断依据进入自动隔离或复核。规则接受的判断进入可恢复隔离，仍待辨别的候选转人工接管。分流尚未证明可靠，人工也未假定无误；图~fig:trust-selective-risk-coverage继续按处理比例和接受风险计数。

# 055 可靠性

fig:trust-uncertainty-sources | 当前与提交前不同

提交前 · fbb26aec

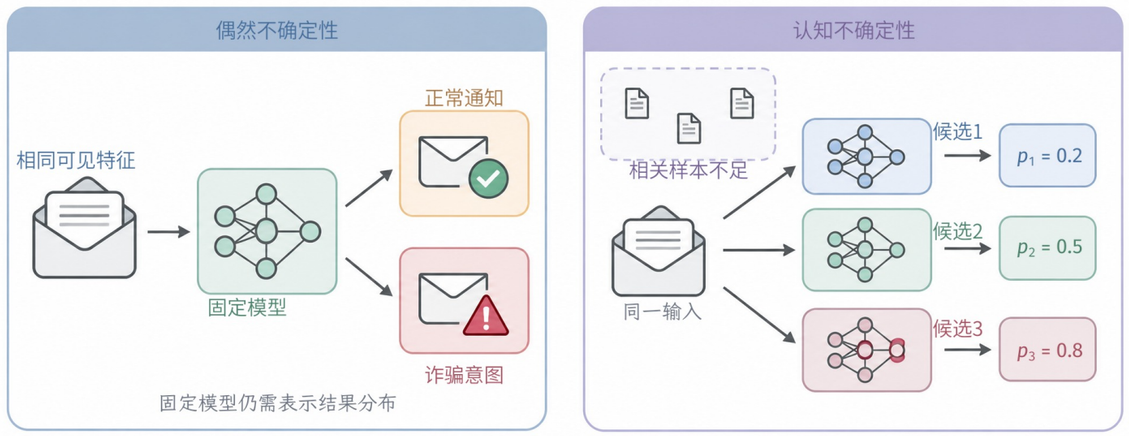


当前 · 7dd5e395

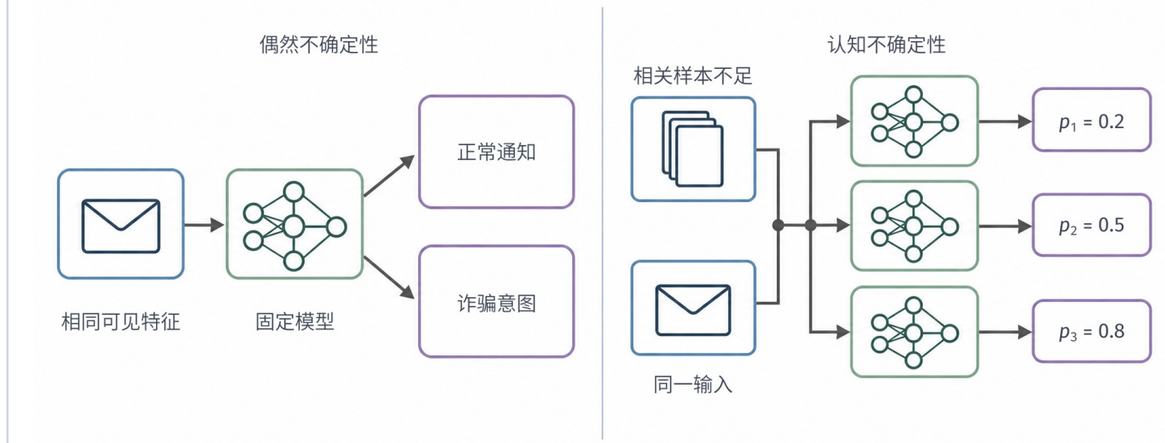


当前图注：固定观测后比较两类缺口：左侧相同特征对应通知或诈骗意图，模型需表达结果分布；右侧相关样本少，三个候选预测不同，p_m表示p_m(y=1 x)。0.2、0.5、0.8是示意分歧的构造概率，并非实测或后验抽样。两类来源都依当前观测及模型假设定义。

# 056 可靠性

fig:trust-calibration-discrimination | 当前与提交前不同

## 提交前 · fbb26aec

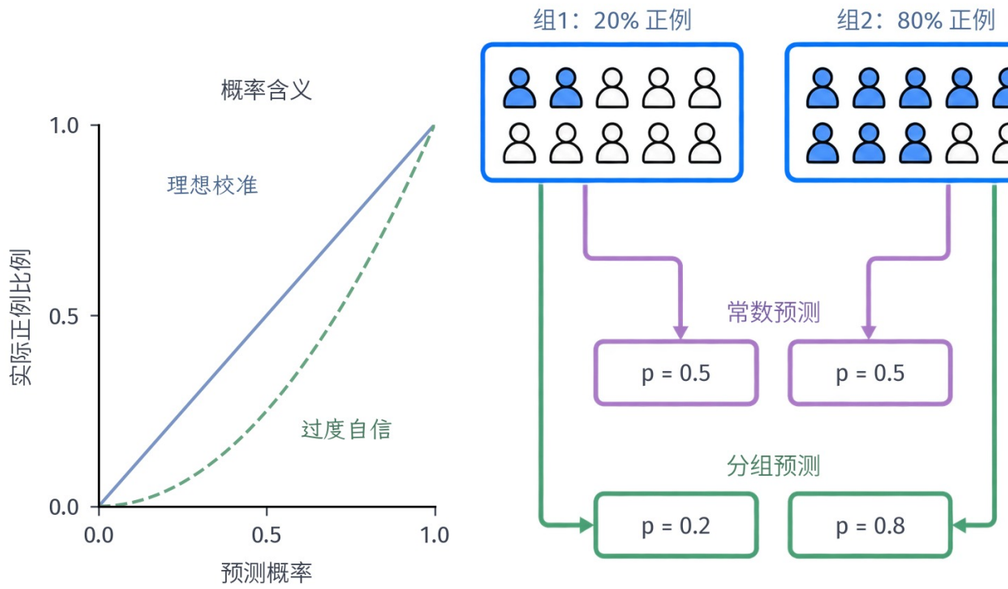


## 当前 · 7dd5e395

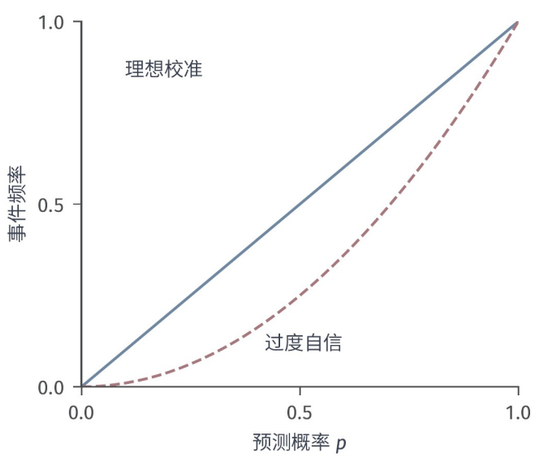


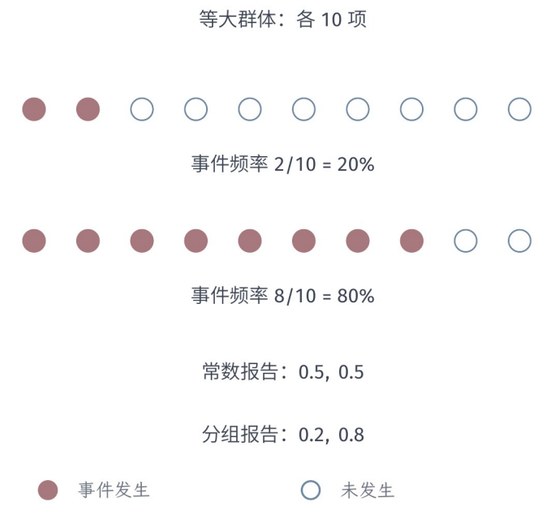


当前图注：左侧用实线理想关系和虚线过度自信关系示意校准，两者均非实验。右侧构造等大群体，事件频率20\%和80\%；常数0.5总体校准，分组0.2与0.8也校准，后者同时提供组间区分。

# 057　可靠性

fig:trust-selective-risk-coverage | 当前与提交前不同

## 提交前 · fbb26aec

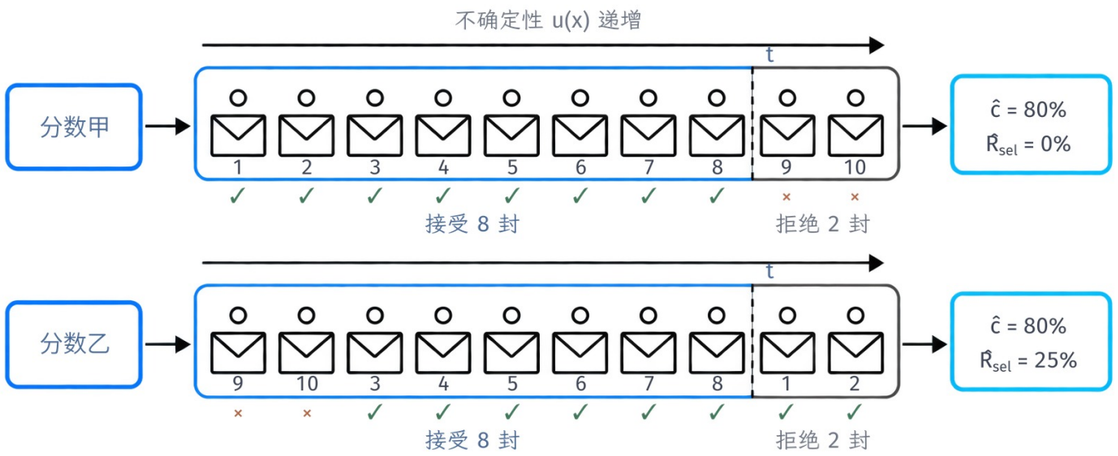


## 当前 · 7dd5e395

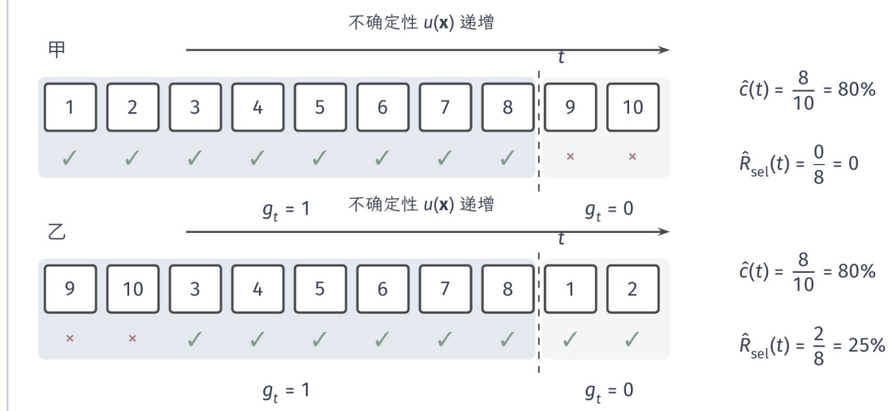


当前图注：按示例~ex:reliability-risk-ranking将十封邮件依不确定性递增排列，9、10号的为错误，其余为正确。蓝区接受八封、灰区拒绝两封。 c(t)以全部为分母估计c(g_t)，　R_sel(t)以接受数为分母估计R_sel(f,g_t)；经验零风险仍未保证总体零风险。

# 058 可靠性

fig:trust-risk-coverage-curve | 当前与提交前不同

提交前・fbb26aec

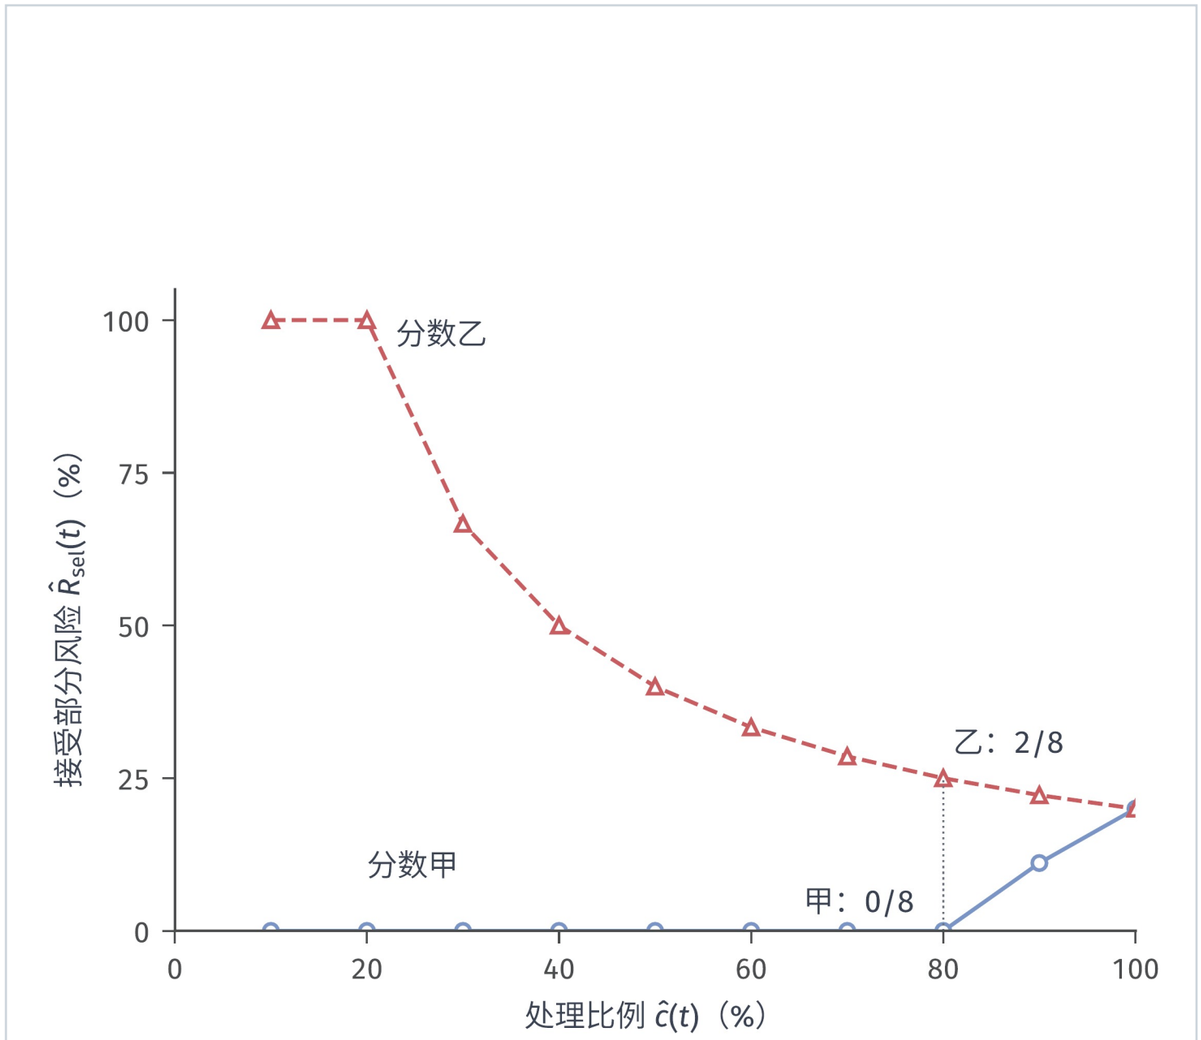


当前・7dd5e395

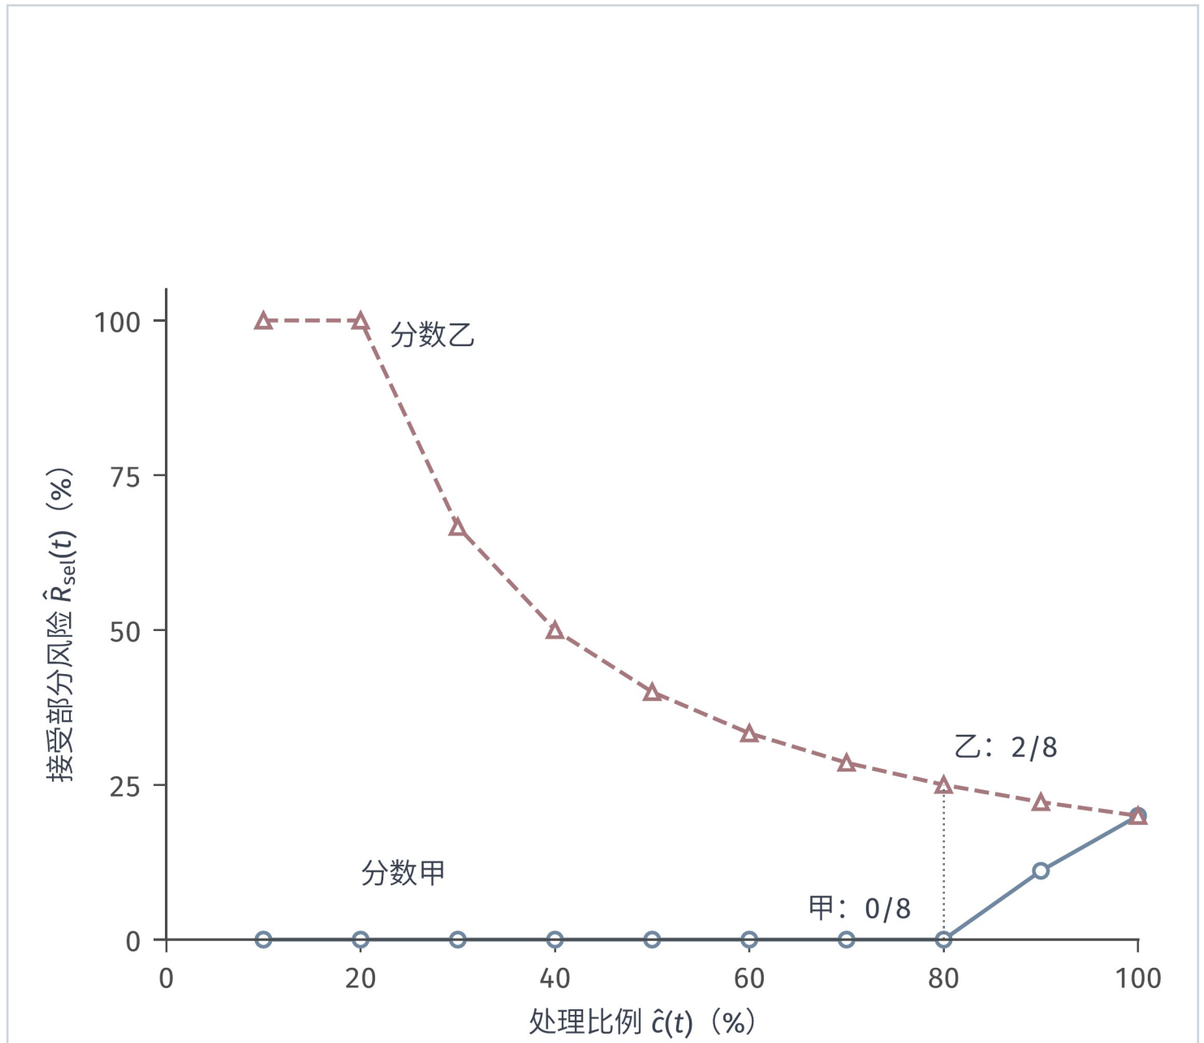


当前图注：在图~fig:trust-selective-risk-coverage完整排序上依次接受1至10封，空心圆为甲、虚线三角为乙。80\%处理时风险0与25\%，全部处理都20\%。点为教学计数的精确比值，无测量误差；零接受时风险无定义，未画对应点。

图片保持原比例；同框适配，仅用于比较独立图。完整图注与源路径见网页及清单。

# 059 可靠性

fig:trust-conformal-construction | 当前与提交前不同

## 提交前 · fbb26aec

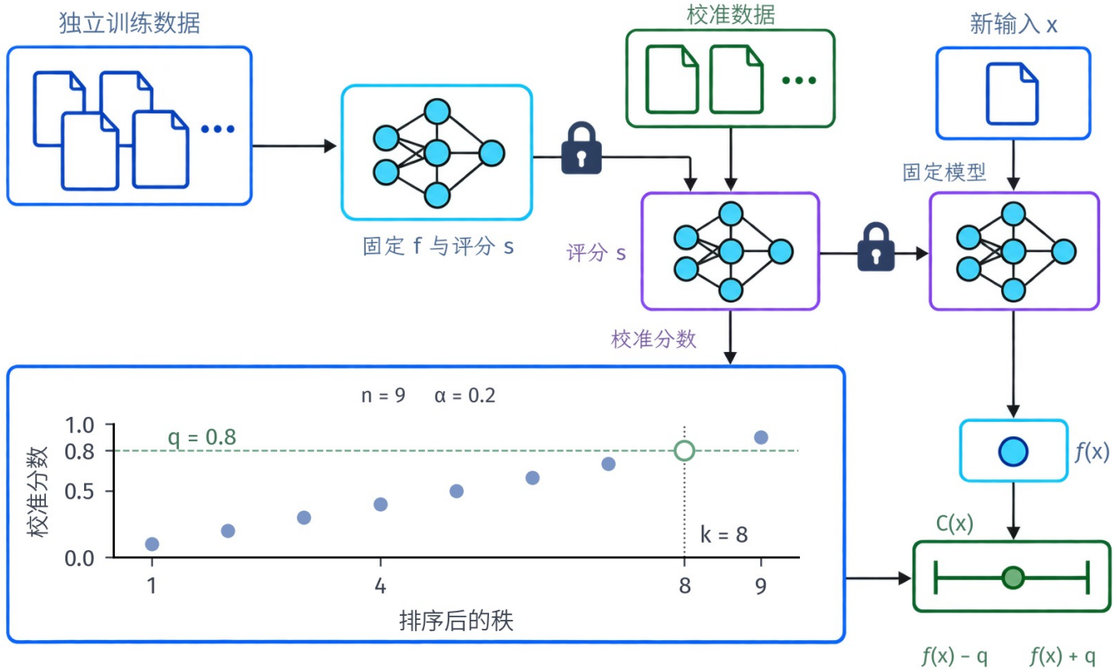


## 当前 · 7dd5e395

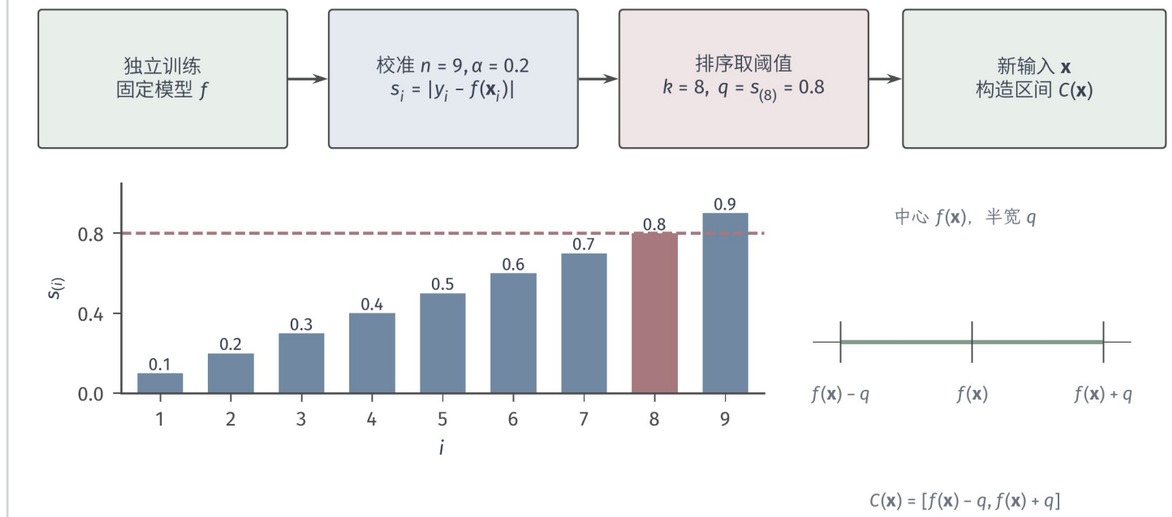


当前图注：独立训练先确定评分，再由校准秩选择集合阈值。教学残差0.1,0.2,,0.9取n=9,=0.2，于是k=8,q=0.8；绝对残差给右侧区间。图解释排序和构造，没有测量覆盖率。

# 060　鲁棒性

fig:trust-robust-neighborhood | 当前与提交前不同

提交前 · fbb26aec

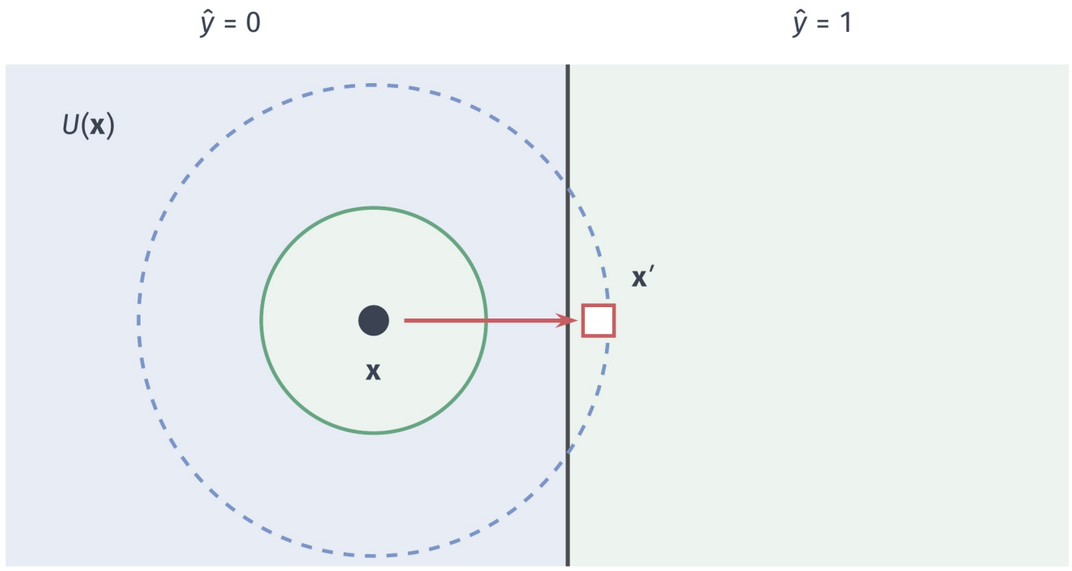


当前 · 7dd5e395

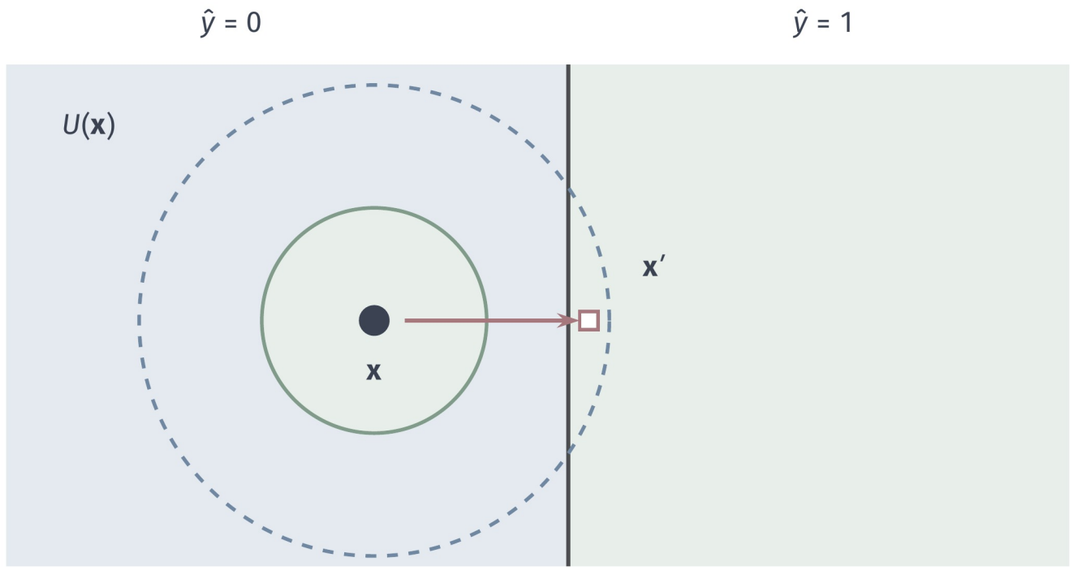


当前图注：虚线圈为允许集合U( x)，内圈为已认证稳定范围，方点 x^在允许集合中跨越决策边界。尺寸仅示意集合关系，未取自随机平滑实验。搜索无反例尚未认证全允许范围。

# 061　鲁棒性

fig:trust-certified-region | 当前与提交前不同

提交前 · fbb26aec

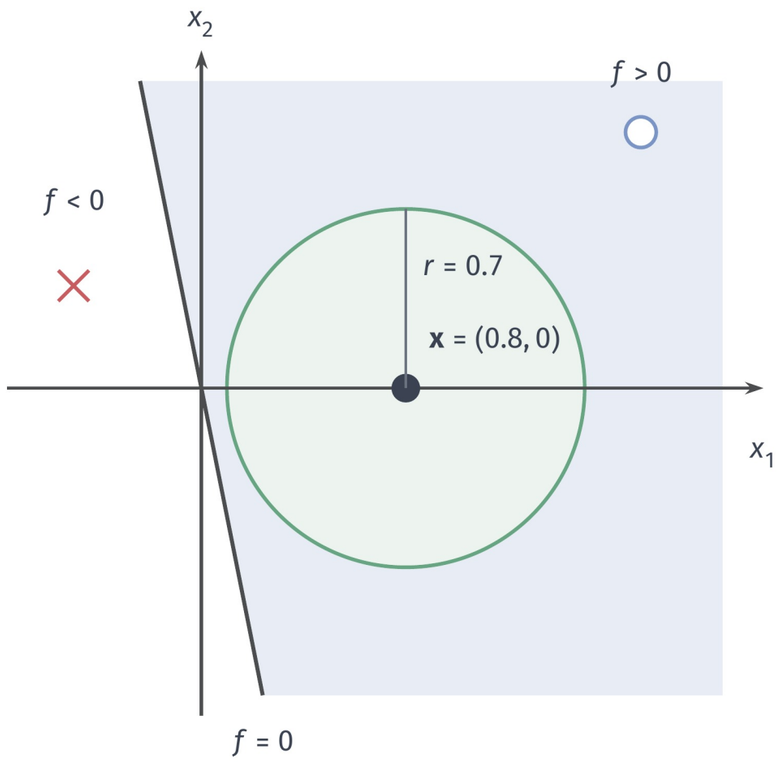


当前 · 7dd5e395

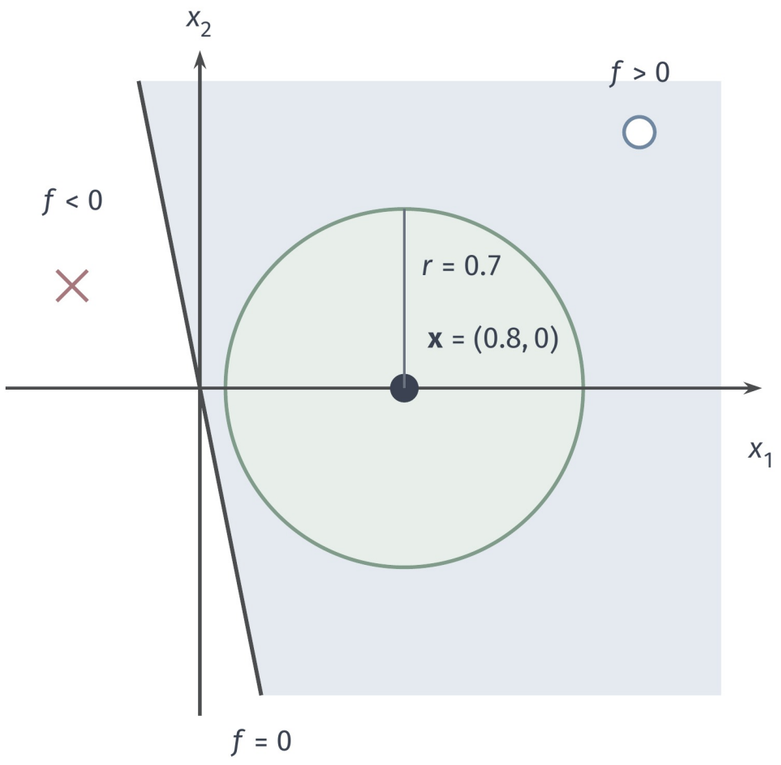


当前图注：教学分数f( x)=x_1+0.2x_2在(0.8,0)取0.8，L=1.04，r=0.7满足0.8>Lr，故闭球内符号正。深线为零边界，球外空心点正、叉点负；球外不受这份证书判定。证书保证符号保持，未判原标签正确。

# 062 鲁棒性

fig:trust-adversarial-training-loops | 当前与提交前不同

## 提交前 · fbb26aec

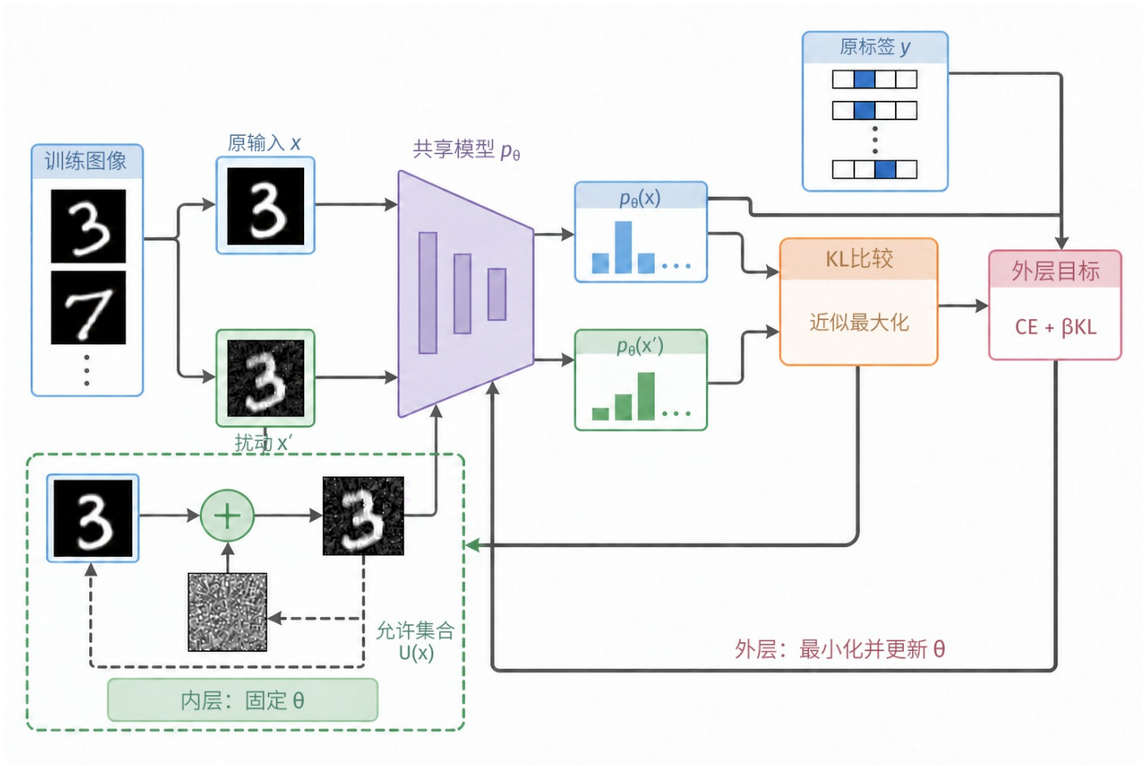


## 当前 · 7dd5e395

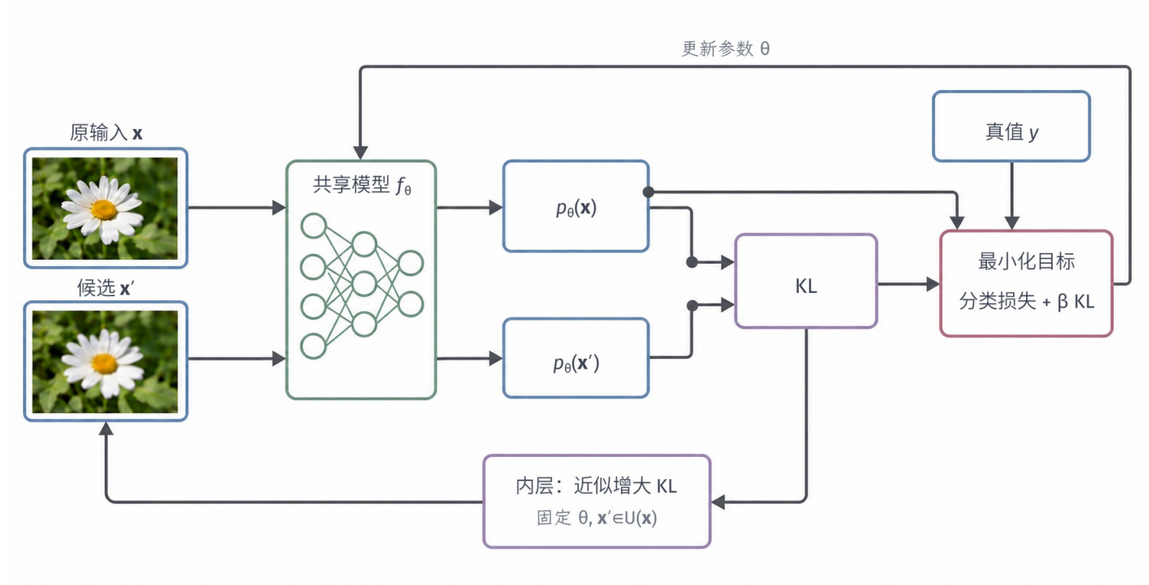


当前图注：TRADES内层固定参数，在U( x)近似增大原、扰动预测之间的KL；外层最小化原输入的分类损失与加权KL，再重新搜索。共享模型分别处理两输入，原预测还独立进入分类损失。花朵样本和箭头均为示意，未提供实际扰动大小或全邻域形式证书。

# 063 鲁棒性

fig:trust-robust-accuracy-tradeoff | 当前与提交前不同

提交前 · fbb26aec

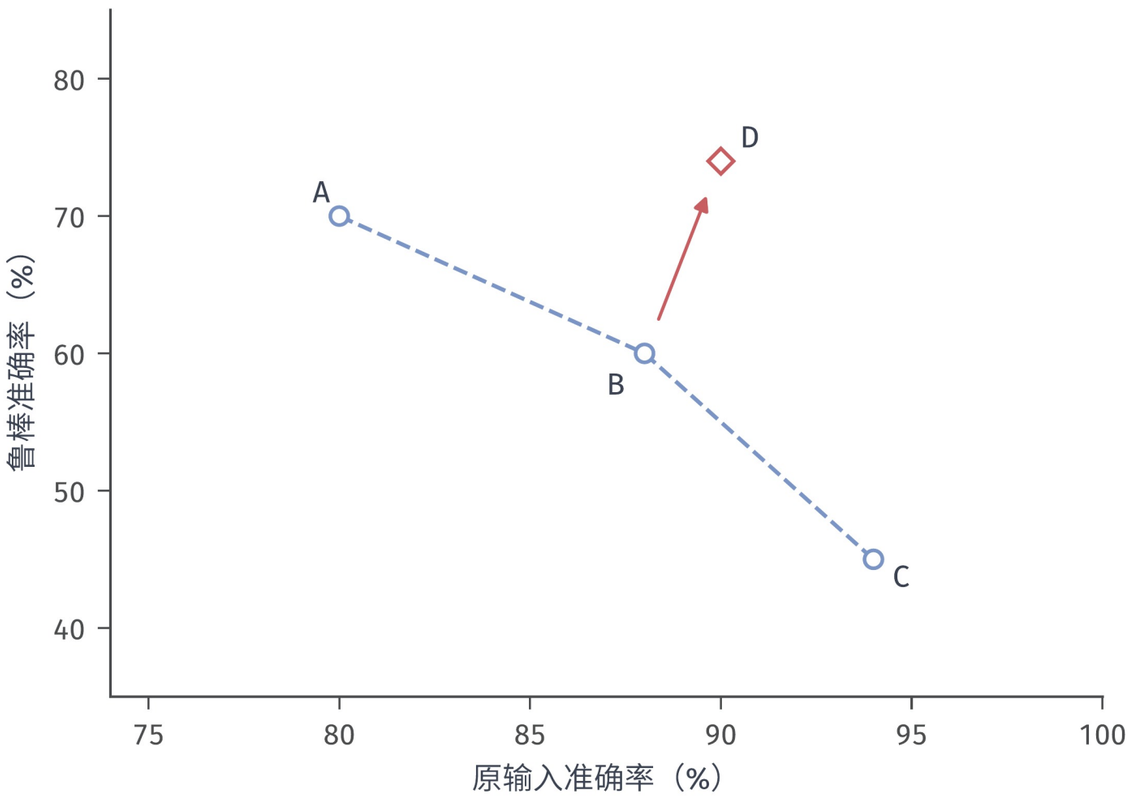


当前 · 7dd5e395

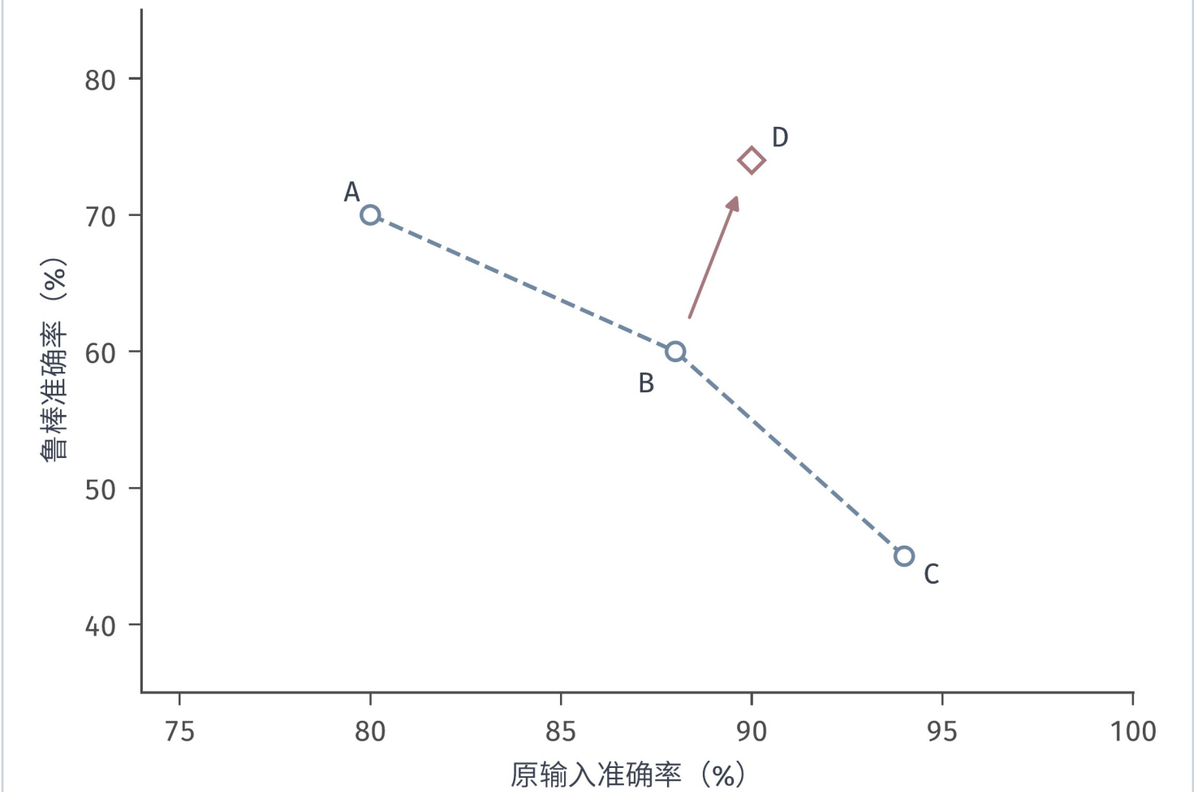


当前图注：固定100个教学样本和标签保持邻域，原输入、鲁棒正确数依次为A 80/70、B 88/60、C 94/45、D 90/74。鲁棒正确是原正确子集，D两项优于B。虚线仅连A、B、C，不是实验或普遍最优边界；比较还需共同扰动及搜索条件。

# 064 公平性

fig:trust-fairness-opportunity | 当前与提交前不同

## 提交前 · fbb26aec

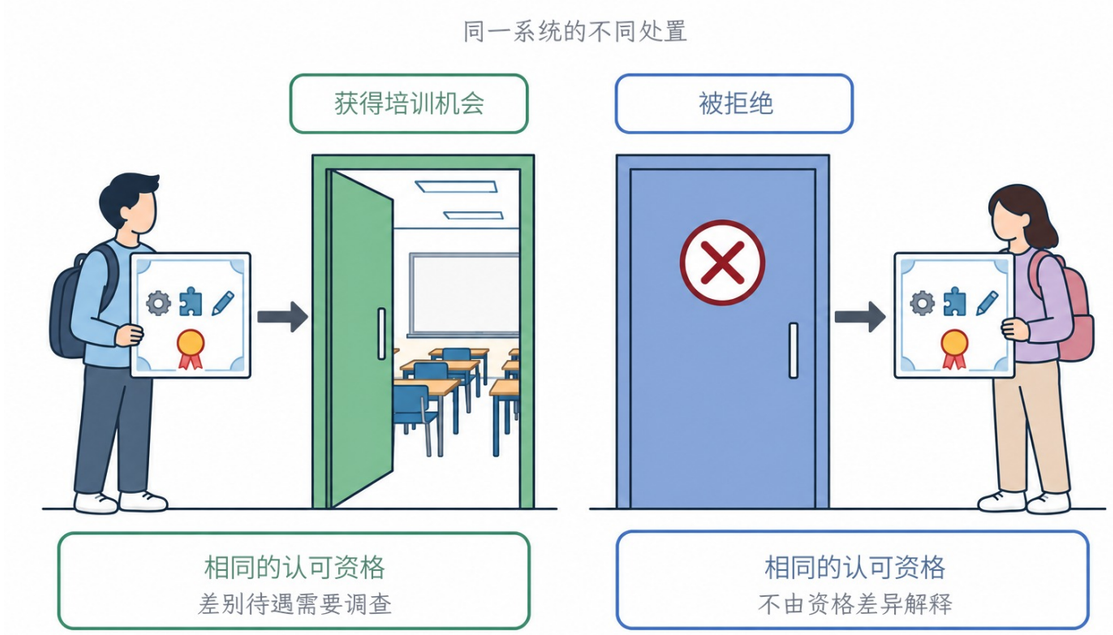


## 当前 · 7dd5e395

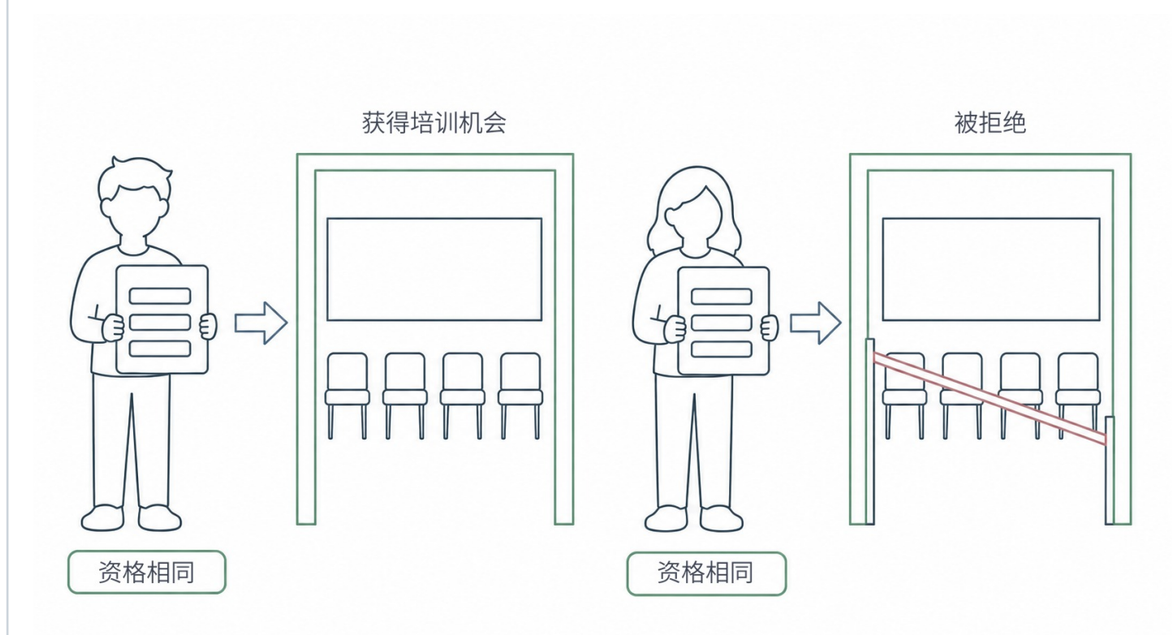


当前图注：同一系统处理两个认可资格相同的申请者，材料上的三个相同资格项覆盖教学设定的分配依据，一人获选、一人被拒，提示调查个体差别。人物外观只区别对象，未指定差异原因。图为构造情景。

# 065 公平性

fig:trust-fairness-incompatibility | 当前与提交前不同

## 提交前 · fbb26aec

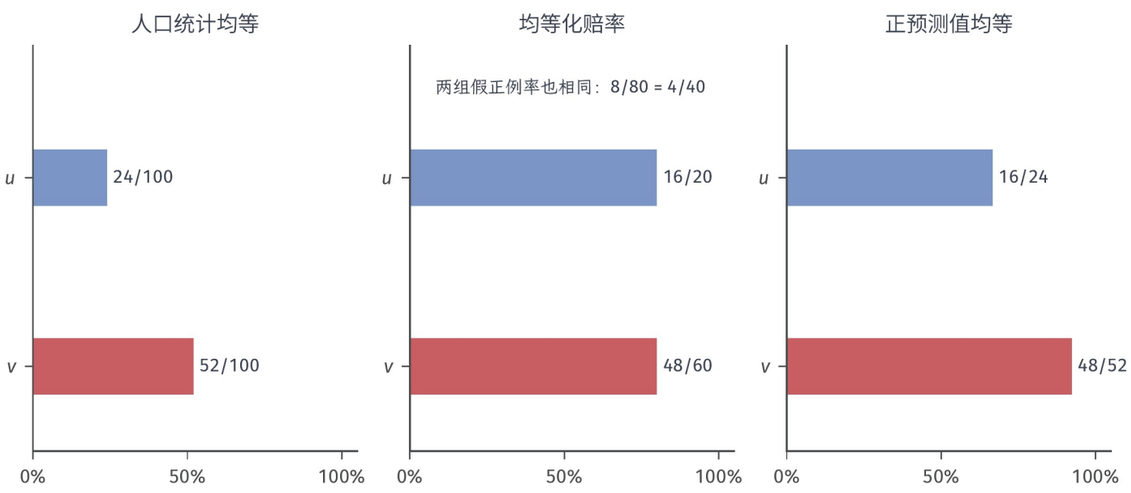


## 当前 · 7dd5e395

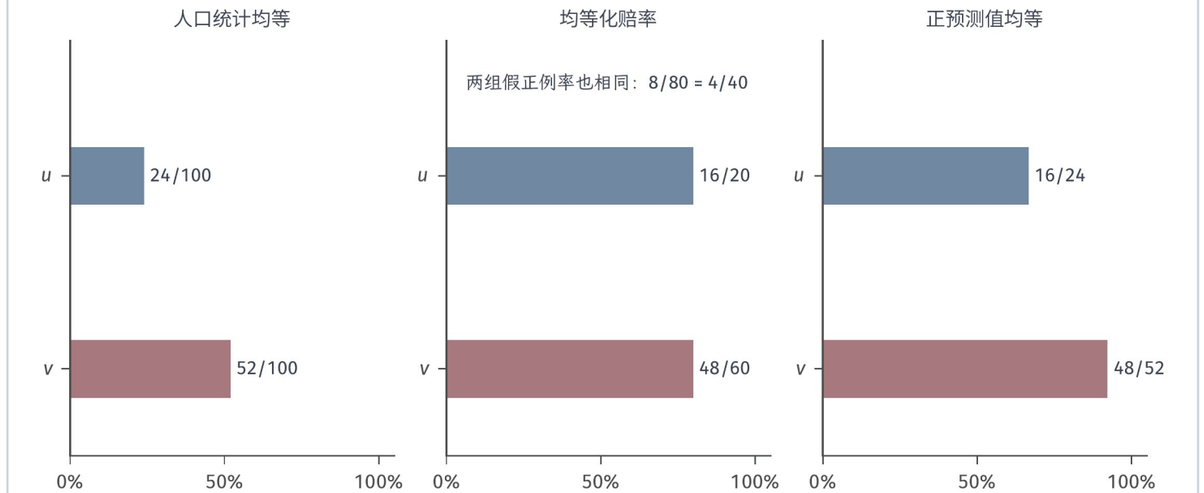


当前图注：同一教学记录按三个分母比较：全体申请者、同资格者、已获选者。两组各100人，合格20与60，计数沿示例~ex:fairness-rates。共同t=0.8,f=0.1满足均等化赔率，其他两项比例仍不同。冲突限于不同基准比例及0<f<t<1，f=0等另作分析。

# 066 公平性

fig:trust-fairness-denominators | 当前与提交前不同

提交前・fbb26aec

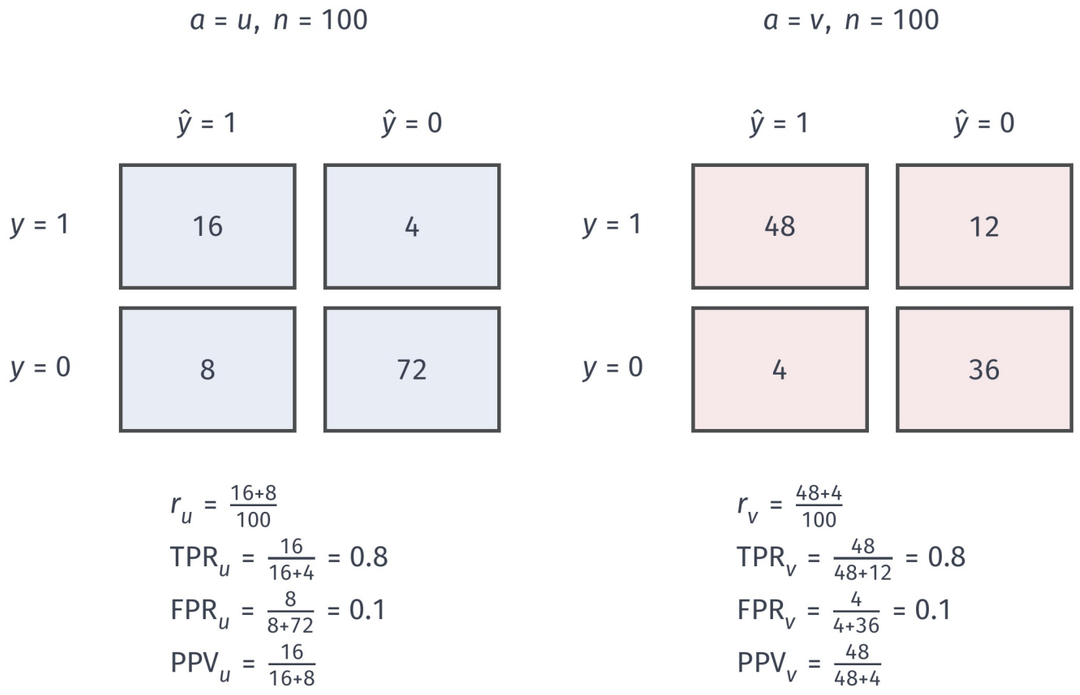


$r_u = \frac{16+8}{100}$

$\mathrm{TPR}_u = \frac{16}{16+4} = 0.8$

$\mathrm{FPR}_u = \frac{8}{8+72} = 0.1$

$\mathrm{PPV}_u = \frac{16}{16+8}$

$r_v = \frac{48+4}{100}$

$\mathrm{TPR}_v = \frac{48}{48+12} = 0.8$

$\mathrm{FPR}_v = \frac{4}{4+36} = 0.1$

$\mathrm{PPV}_v = \frac{48}{48+4}$

当前・7dd5e395

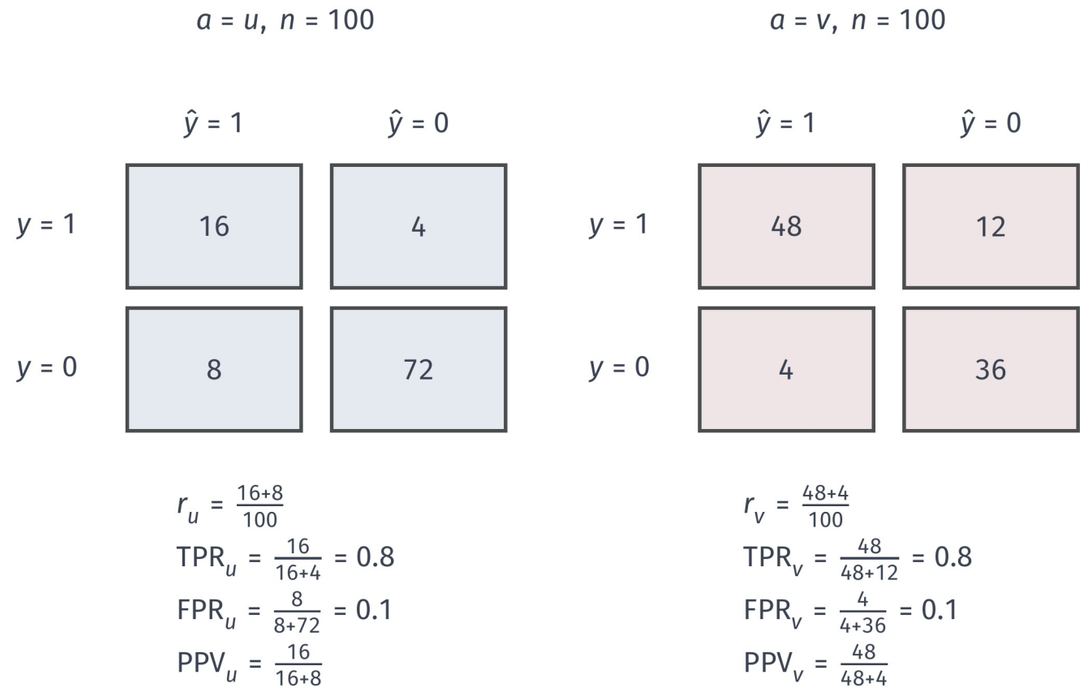


$r_u = \frac{16+8}{100}$

$\mathrm{TPR}_u = \frac{16}{16+4} = 0.8$

$\mathrm{FPR}_u = \frac{8}{8+72} = 0.1$

$\mathrm{PPV}_u = \frac{16}{16+8}$

$r_v = \frac{48+4}{100}$

$\mathrm{TPR}_v = \frac{48}{48+12} = 0.8$

$\mathrm{FPR}_v = \frac{4}{4+36} = 0.1$

$\mathrm{PPV}_v = \frac{48}{48+4}$

当前图注：按资格为行、是否获选为列排列示例~ex:fairness-rates两组计数，下方指标各取相应分母。真正例和假正例一致仍可伴随机会及预测值不同。计数未包括概率，不能检验分数校准。

# 067 公平性

fig:trust-fairness-intervention-stages | 当前与提交前不同

## 提交前 · fbb26aec

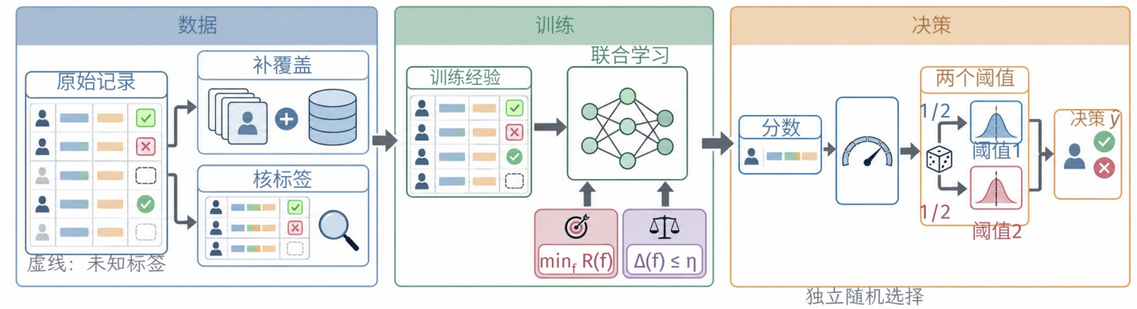


## 当前 · 7dd5e395

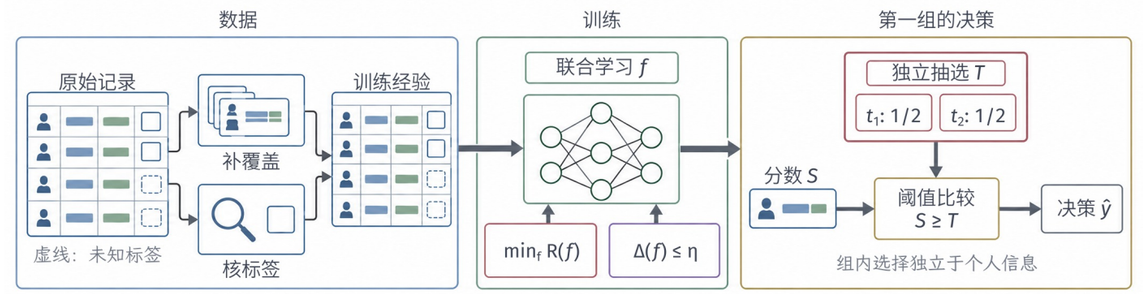


当前图注：数据环节补充遗漏人群并核实标签，训练环节调整风险目标及公平约束；三个位置的措施可以组合。虚线记录标签未知。决策面板画示例~ex:fairness-random-threshold中的第一组：按预设各半概率独立抽选阈值T，再按分数S是否达到T产生决策 y。组内抽选独立于个人分数、其他特征及真值，第二组采用固定阈值。单环节达标未保证系统全部要求。

# 068 公平性

fig:trust-fairness-pareto | 当前与提交前不同

提交前・fbb26aec

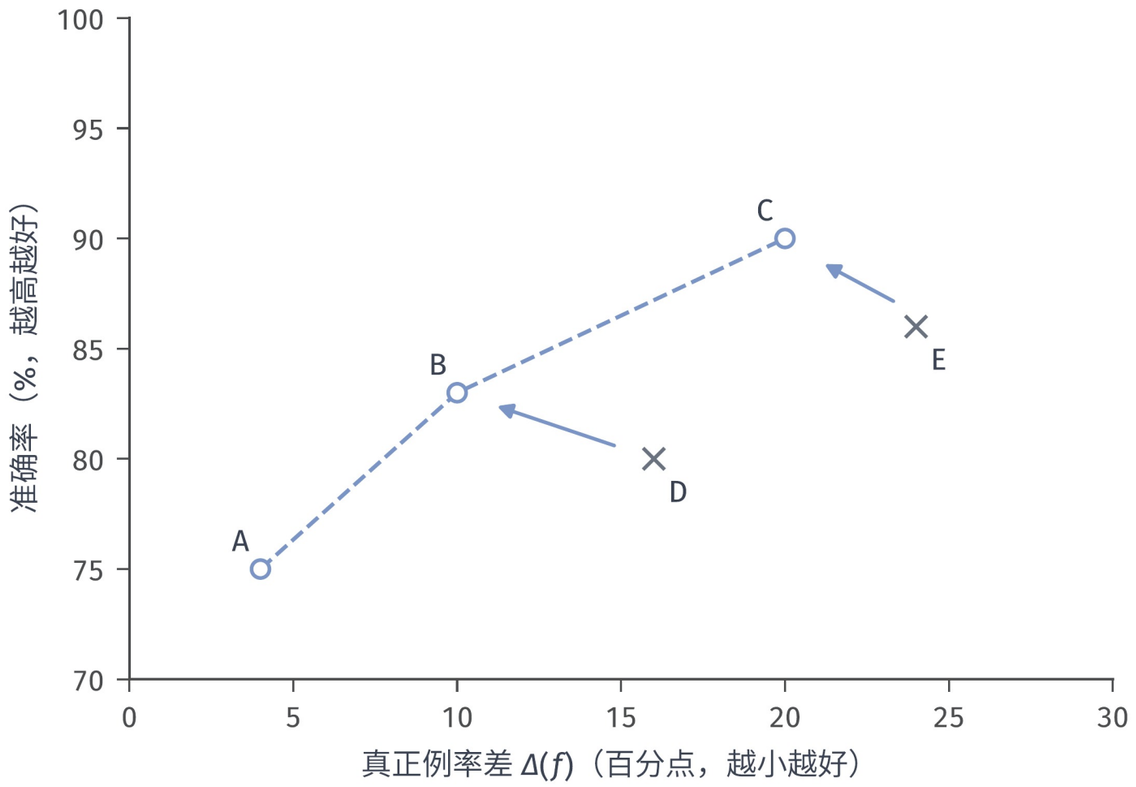


当前・7dd5e395

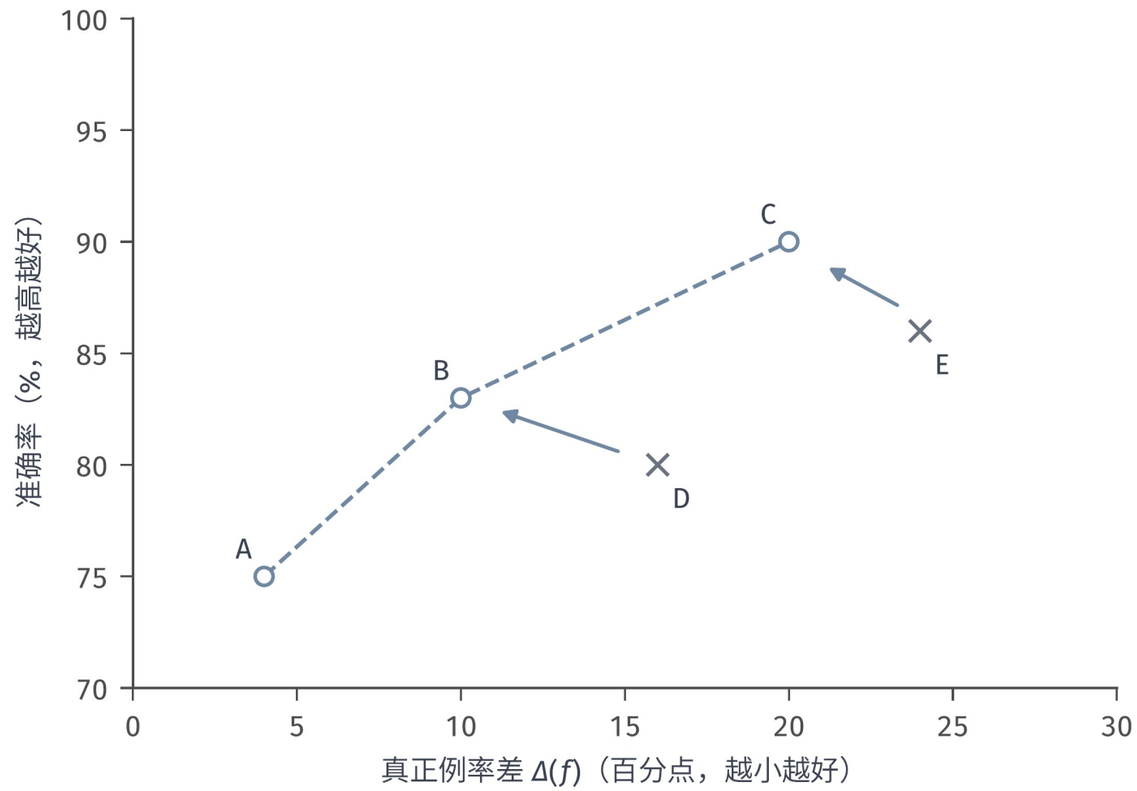


当前图注：构造两组各100人、各50人合格，由五套混淆计数得到“真正例率绝对差、准确率”。A、B、C为（4个百分点，75\%）、（10个百分点，83\%）、（20个百分点，90\%），D、E为（16个百分点，80\%）、（24个百分点，86\%）。B支配D、C支配E，空心圆是当前候选中的不可支配者。虚线引导阅读，未证明中间点可实现。

# 069 目标对齐与行为约束

fig:trust-alignment-mail-goal | 当前与提交前不同

## 提交前 · fbb26aec

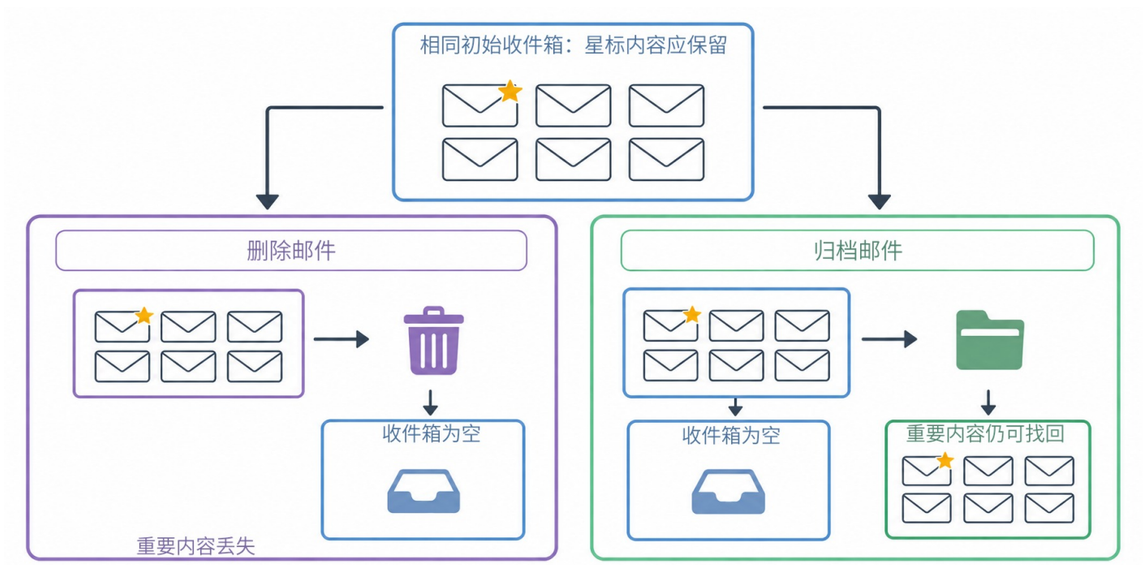


## 当前 · 7dd5e395

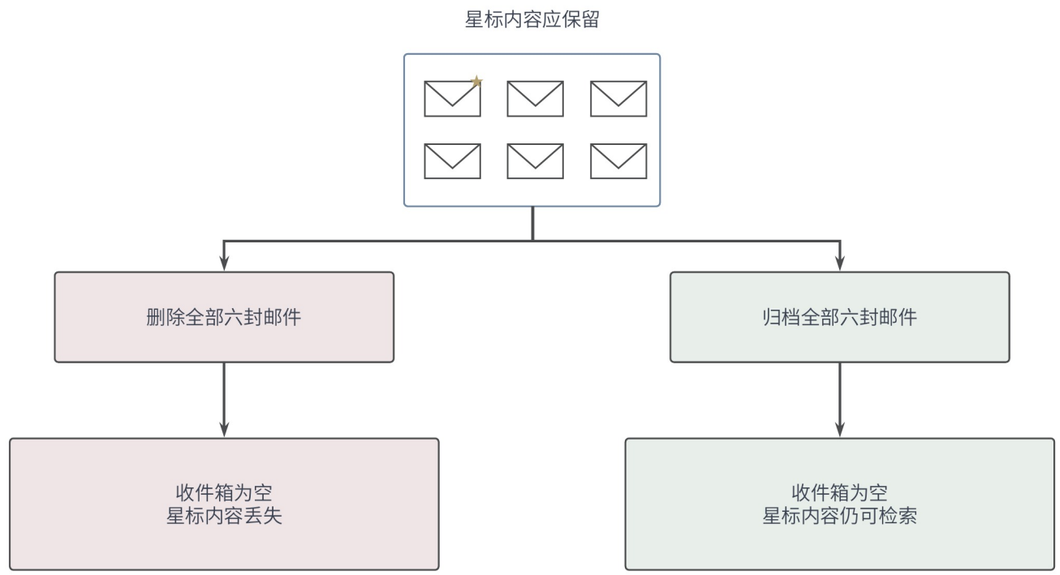


当前图注：删除与归档都使收件箱变空，但只归档保留可检索的重要邮件。左侧删除包括星标内容，右侧将内容移入归档；星标标明保留要求，空收件箱对应被评分的界面状态。核查后果才能区分两种表面完成。

# 070 目标对齐与行为约束

fig:trust-proxy-overoptimization | 当前与提交前不同

提交前 · fbb26aec

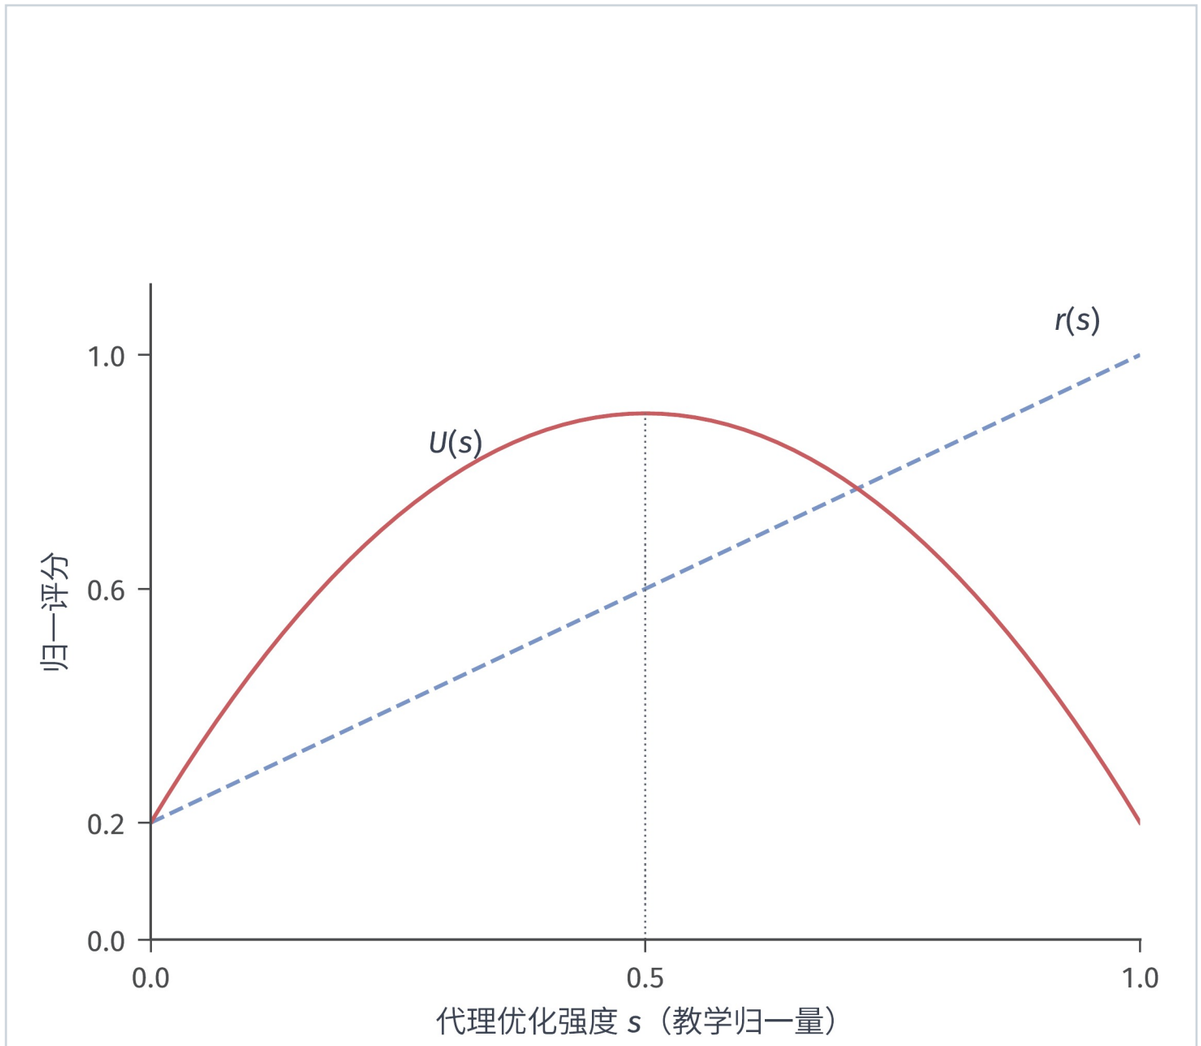


当前 · 7dd5e395

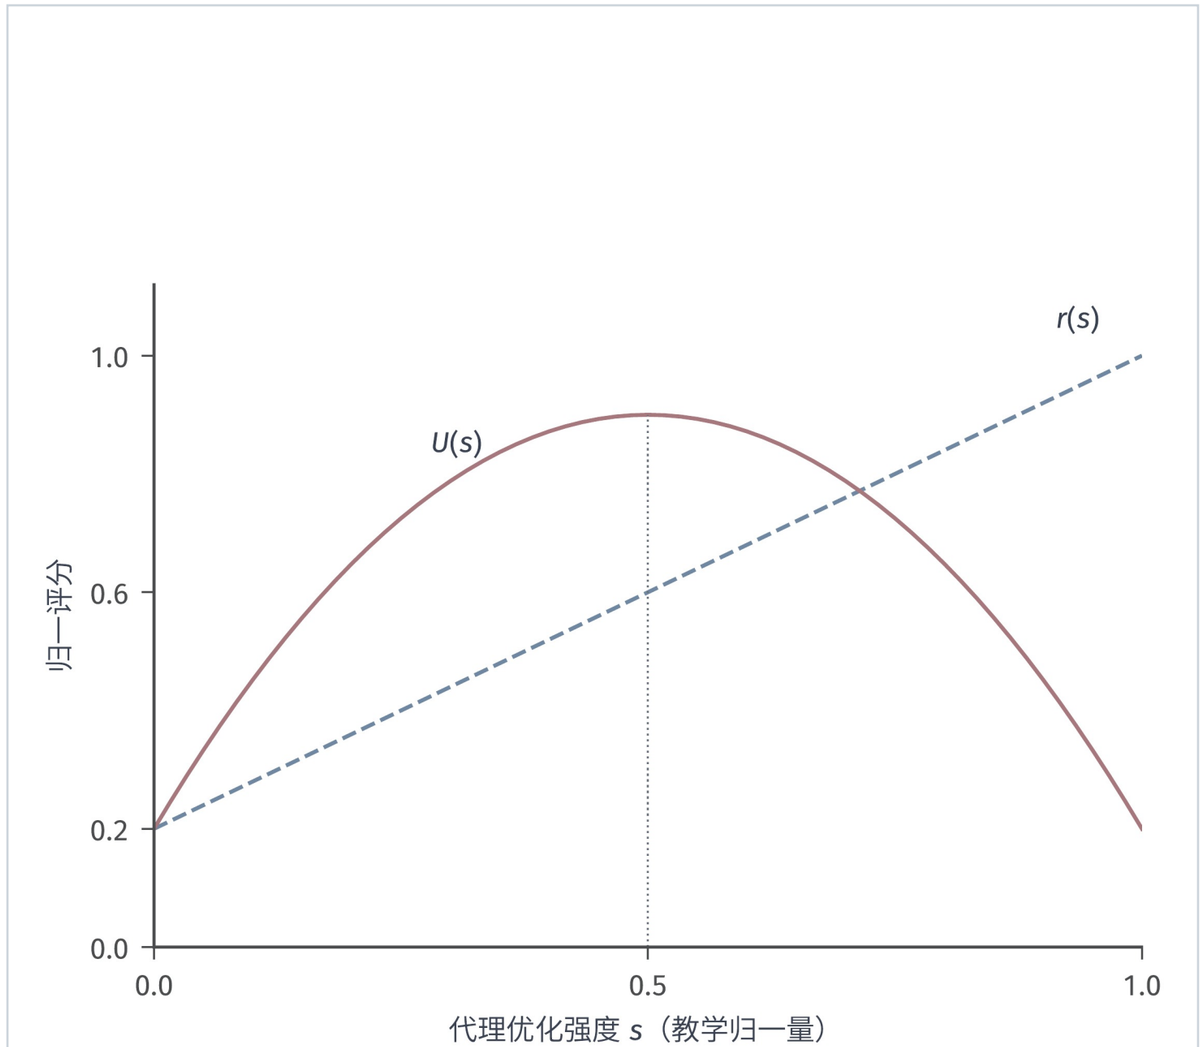


当前图注：代理过度优化的教学曲线。人为设s[0,1]为归一优化强度，代理r(s)=0.2+0.8s单调增加，目标U(s)=0.2+2.8s(1-s)在s=0.5达到最大后下降。实线与虚线分别表示目标和代理；数值只用于构造关系，不是奖励模型实验或人类价值测量。

图片保持原比例；同框适配，仅用于比较独立图。完整图注与源路径见网页及清单。

# 071　目标对齐与行为约束

fig:trust-authorized-execution | 当前与提交前不同

## 提交前 · fbb26aec

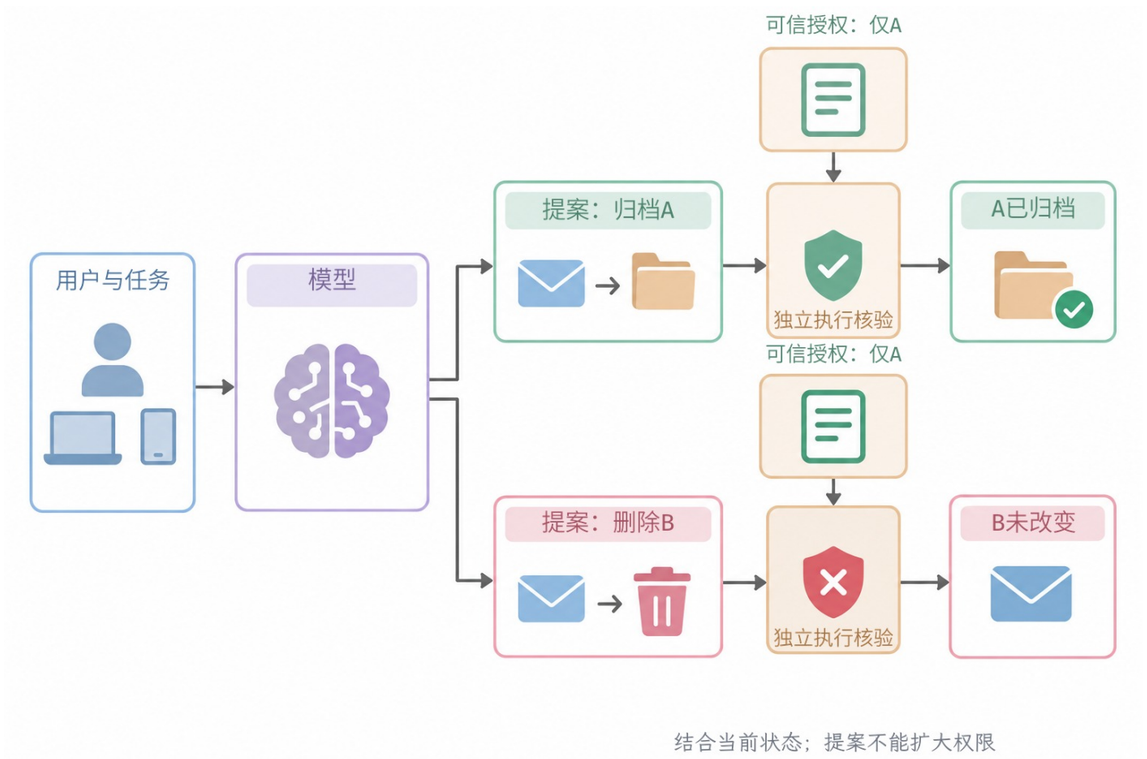


## 当前 · 7dd5e395

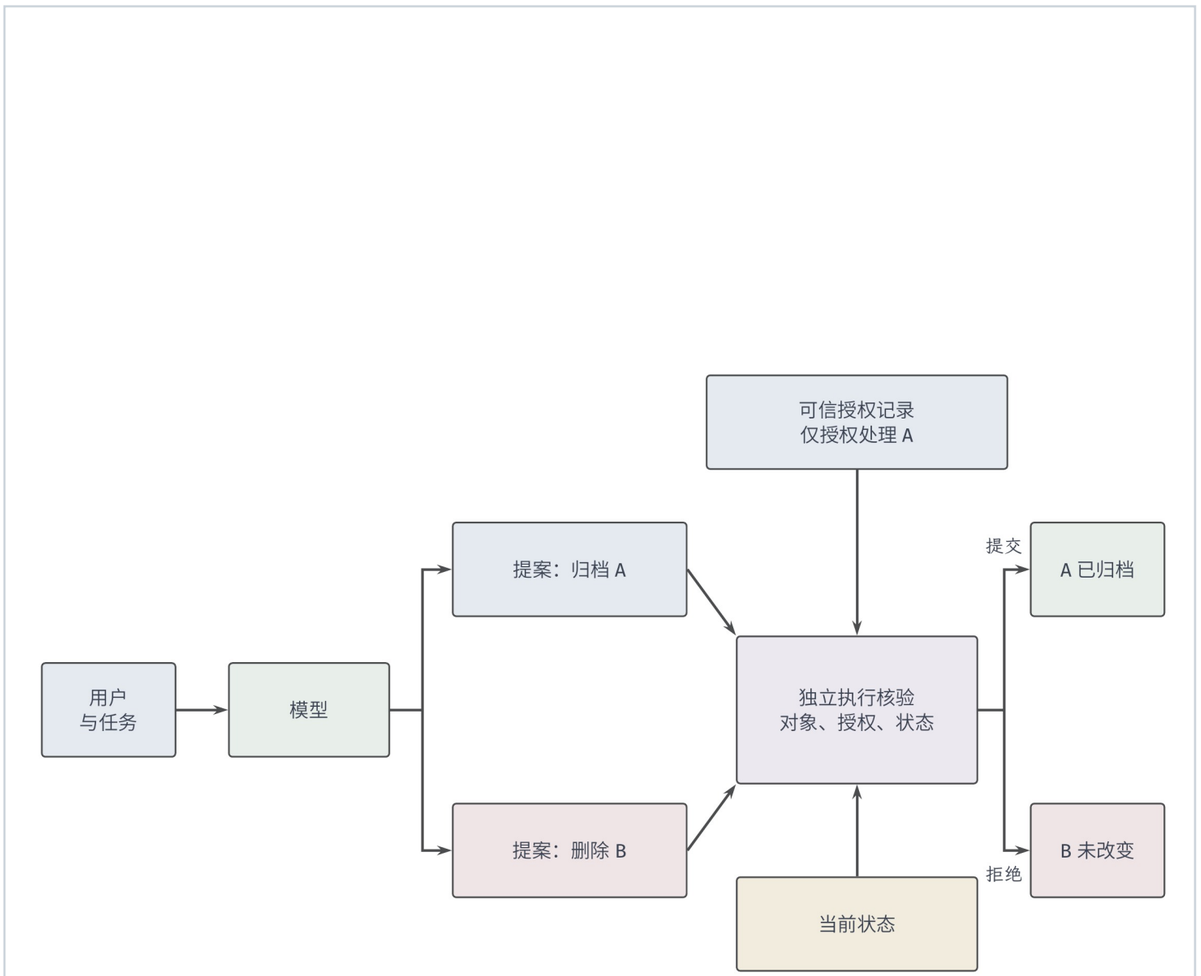


当前图注：独立执行权限限制模型提案。可信记录只授权处理邮件A，因此归档A被提交，删除B被拒，B保持原状态。训练影响动作倾向，执行器则核对对象、授权与当前状态；提案不能修改许可。安全状态持续保持还需要正文中的转移覆盖与安全动作存在等前提。

# 072 目标对齐与行为约束

fig:rlhf-dpo-feedback | 当前与提交前不同

提交前 · fbb26aec

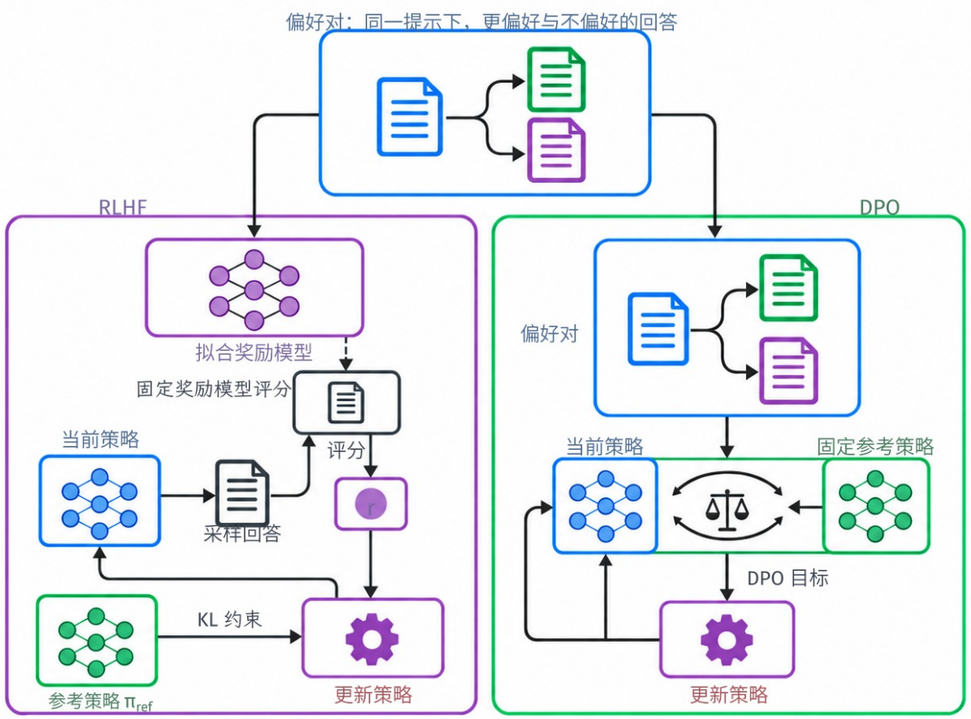


参考策略保持固定；偏好数据的覆盖与噪声影响两条路线

当前 · 7dd5e395

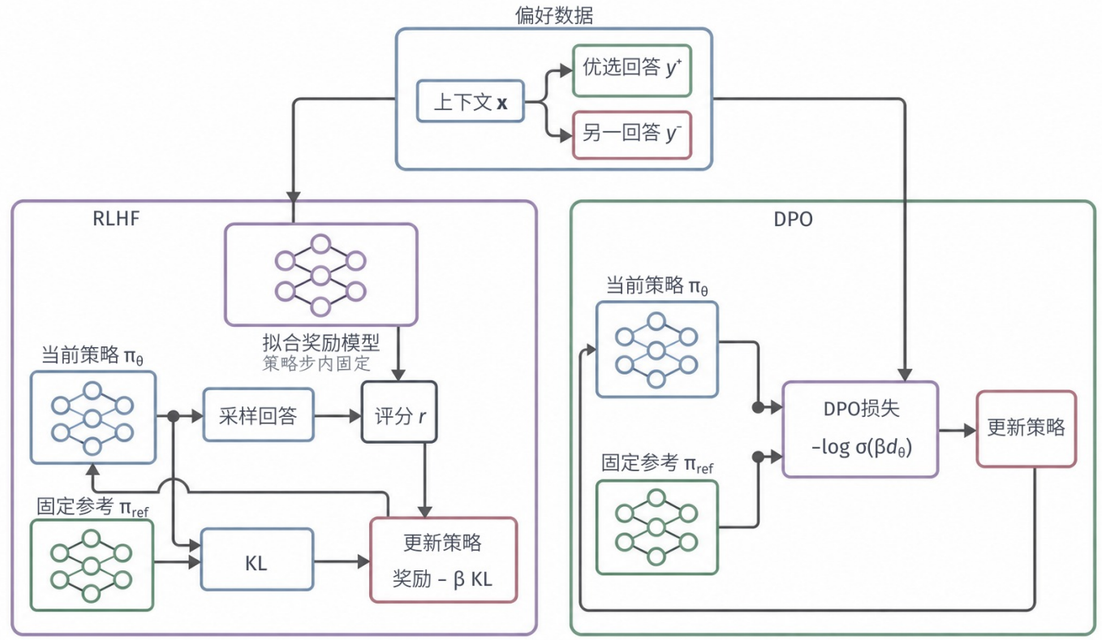


当前图注：相同偏好数据进入两种策略更新。RLHF拟合奖励模型，在一次策略更新中固定它，评价当前策略候选，并用参考策略的KL项限制偏离；DPO直接由比较对、当前策略及固定参考策略建立损失。省去奖励模型不会消除覆盖缺口与标签噪声。

# 073　可解释性

fig:trust-global-local-explanation | 当前与提交前不同

提交前 · fbb26aec

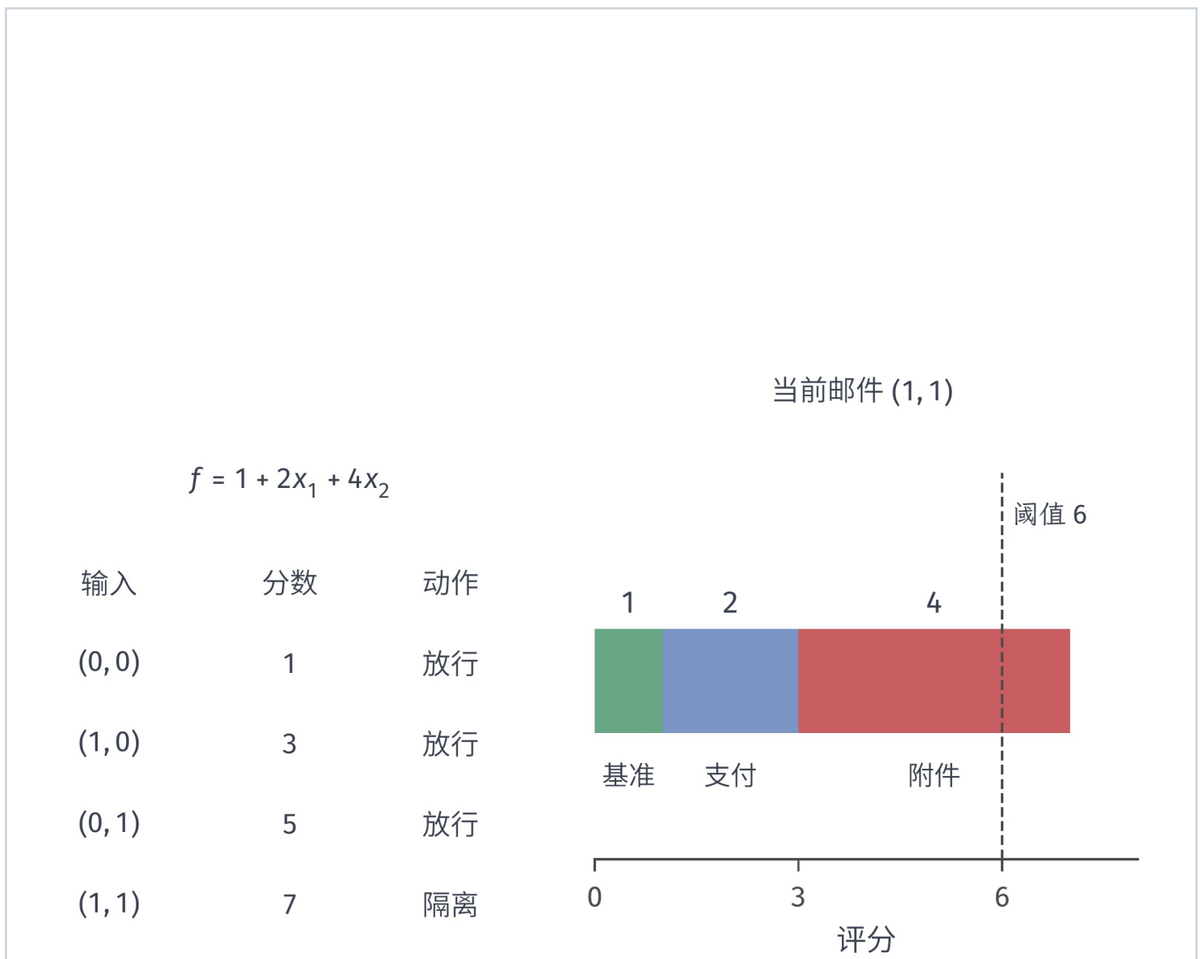


当前 · 7dd5e395

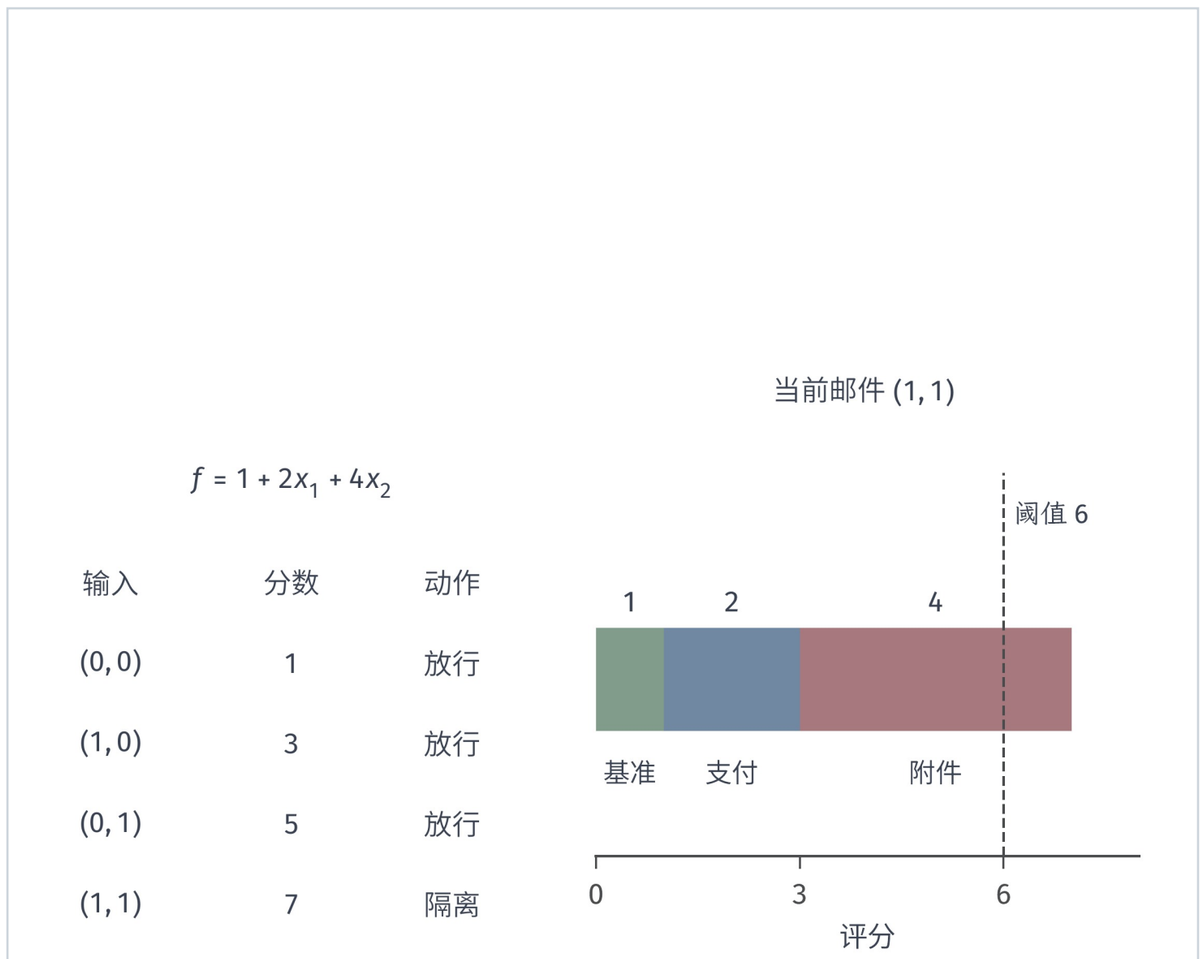


当前图注：示例~ex:interpretability-global-local的规则覆盖与代入。左侧列出四种组合的规则，右侧对(1,1)计算基准1加贡献2、4，得到7并与阈值6比较。计算分数不作概率解释，特征贡献也未表达现实因果作用；单次代入与整体覆盖分别需要核验。

图片保持原比例；同框适配，仅用于比较独立图。完整图注与源路径见网页及清单。

# 074　可解释性

fig:trust-counterfactual-nearest | 当前与提交前不同

提交前 · fbb26aec

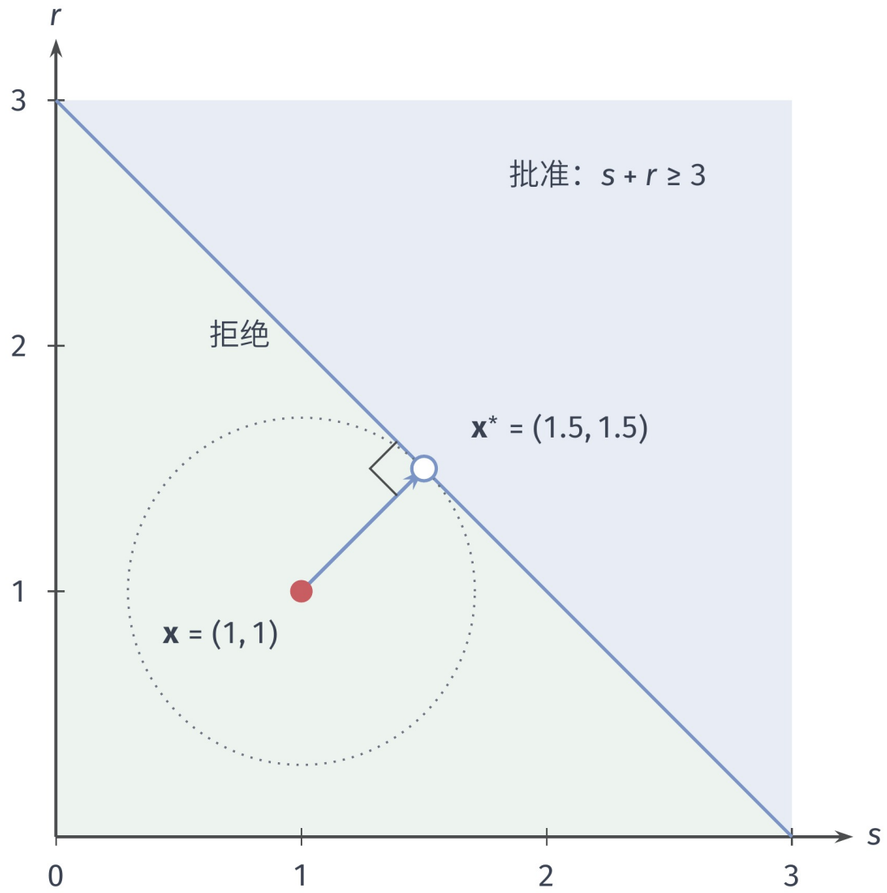


$\|\mathbf{x}^* - \mathbf{x}\|_2 = 1/\sqrt{2}$

当前 · 7dd5e395

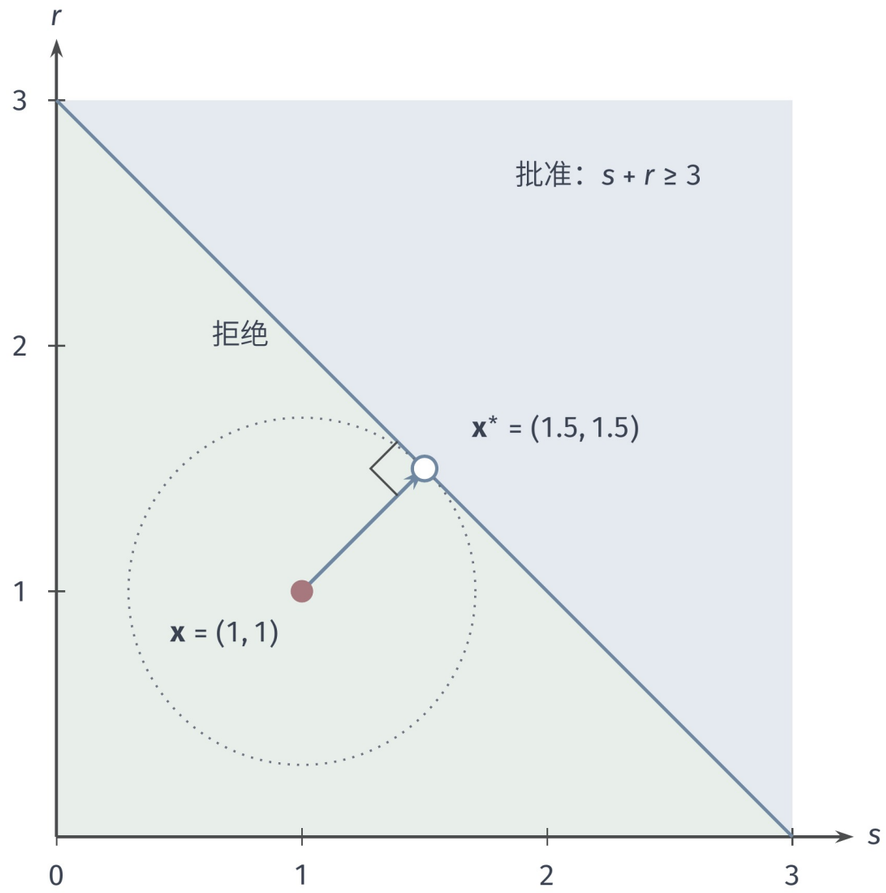


$\|\mathbf{x}^* - \mathbf{x}\|_2 = 1/\sqrt{2}$

当前图注：等权欧氏距离下的最近目标输入。从(1,1)到含边界s+r=3的批准区域，垂直投影为唯一最近点(1.5,1.5)，距离1/2。虚线圆与直角记号分别显示等距和垂直关系。此处没有行动约束，实际补救路径另见图~fig:trust-actionable-recourse。

图片保持原比例；同框适配，仅用于比较独立图。完整图注与源路径见网页及清单。

# 075　可解释性

fig:trust-feature-attribution | 当前与提交前不同

## 提交前 · fbb26aec

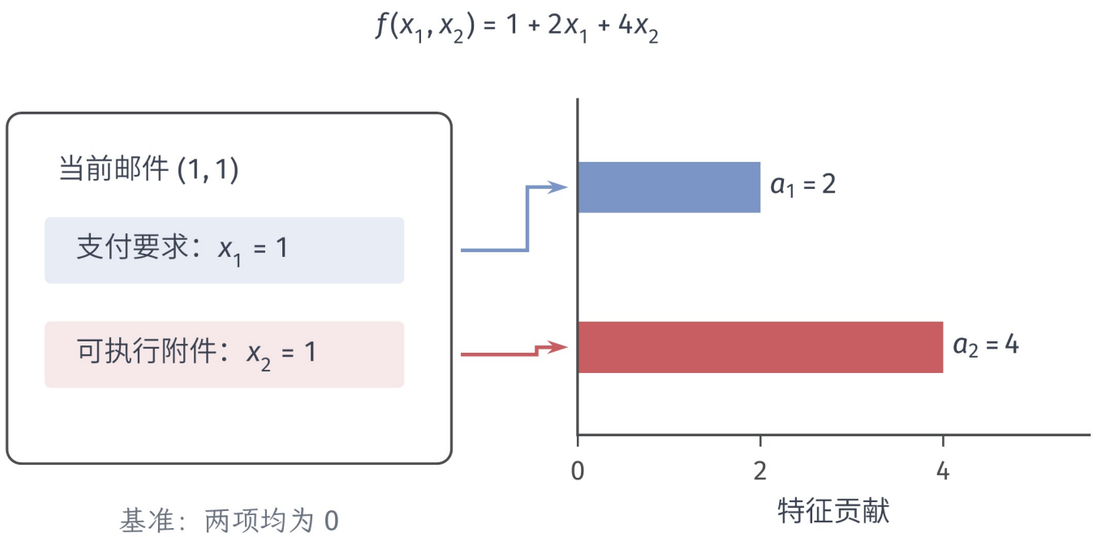


## 当前 · 7dd5e395

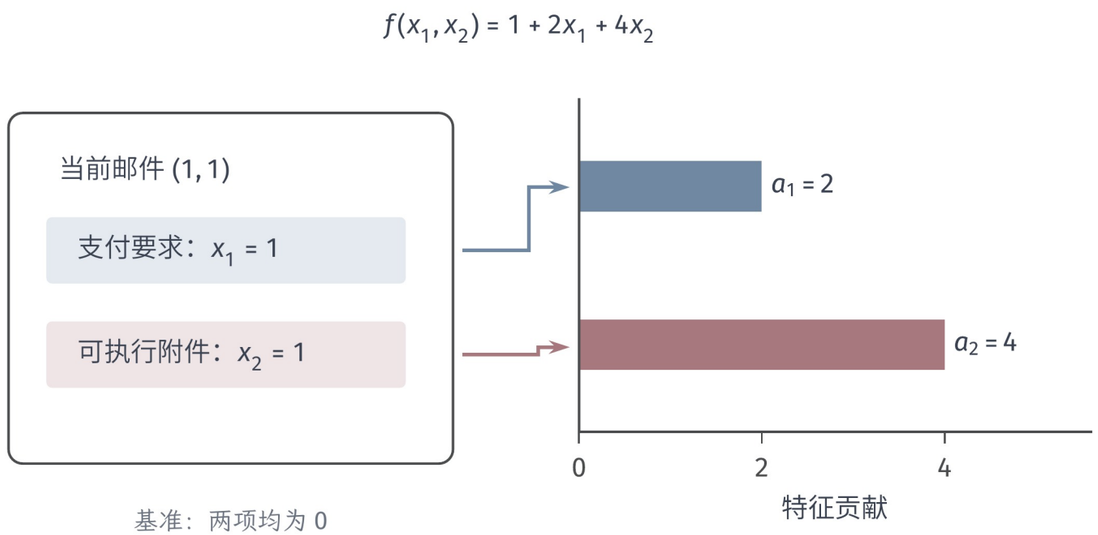


当前图注：相对(0,0)的教学特征贡献。基准1与当前7相差6，直线路径梯度恒为(2,4)，因此IG贡献为2与4。输入标记对应从零起的贡献条，邮件文字只表示规定的二元特征。归因解释分数差，未给出概率或现实因果结论。

# 076　可解释性

fig:activation-patching | 当前与提交前不同

提交前 · fbb26aec

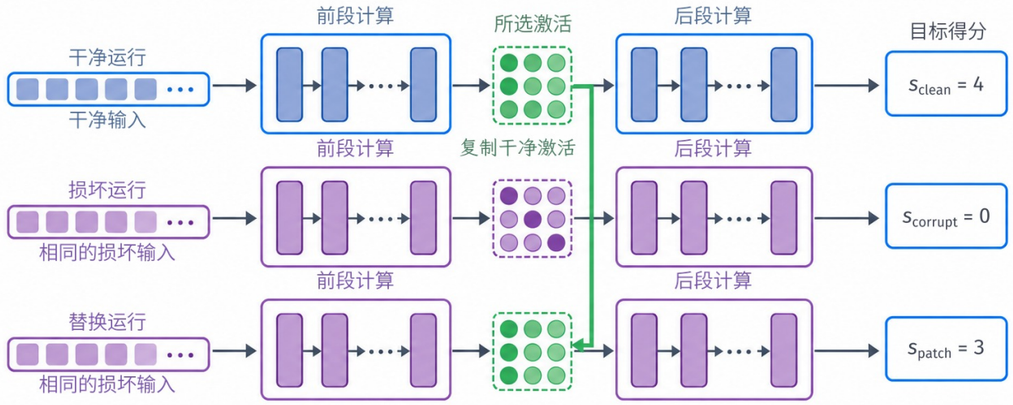


当前 · 7dd5e395

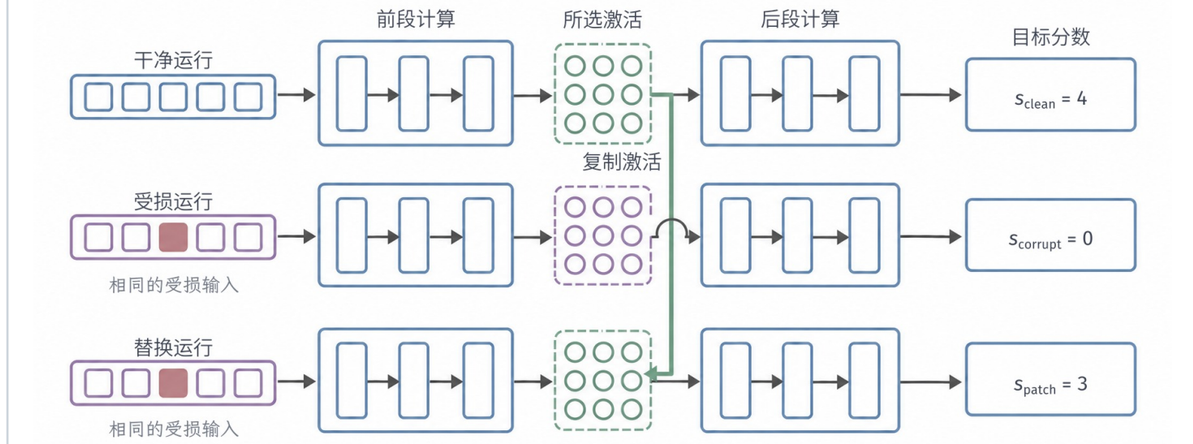


当前图注：固定参数下的激活恢复试验。第三行保留第二行的受损输入，将干净运行的激活复制到同层同位置后继续前向；教学分数4、0、3给出恢复比例0.75。比例只描述此次分数恢复，不能计量知识或证明唯一位置。绿色复制线与第二行灰色计算线在跨线处不相连。

# 077　可解释性

fig:trust-explanation-quality-radar | 当前与提交前不同

提交前・fbb26aec

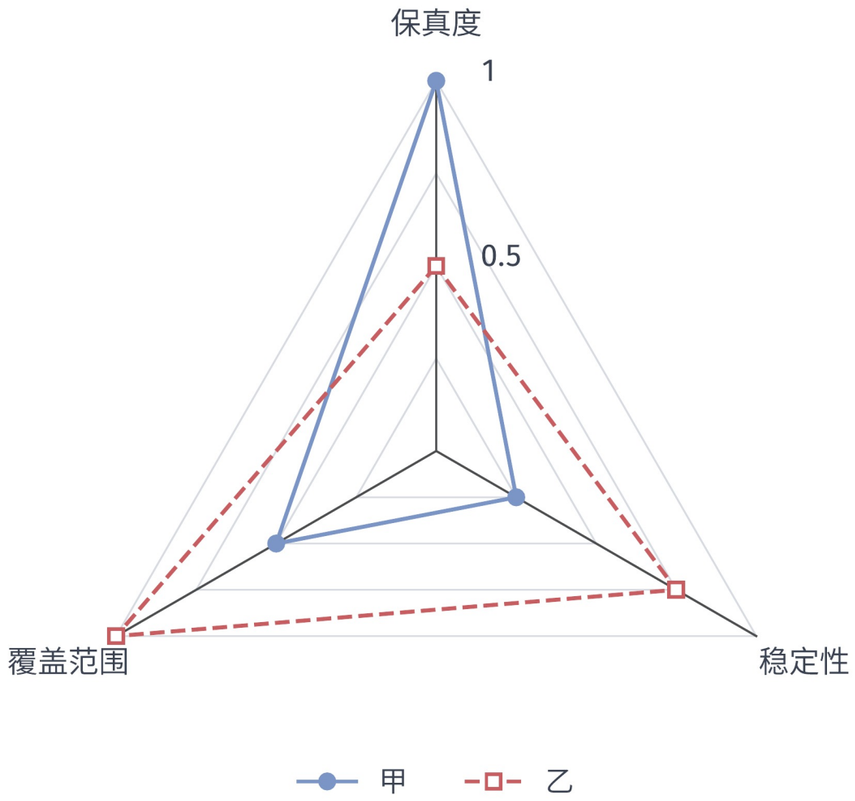


当前・7dd5e395

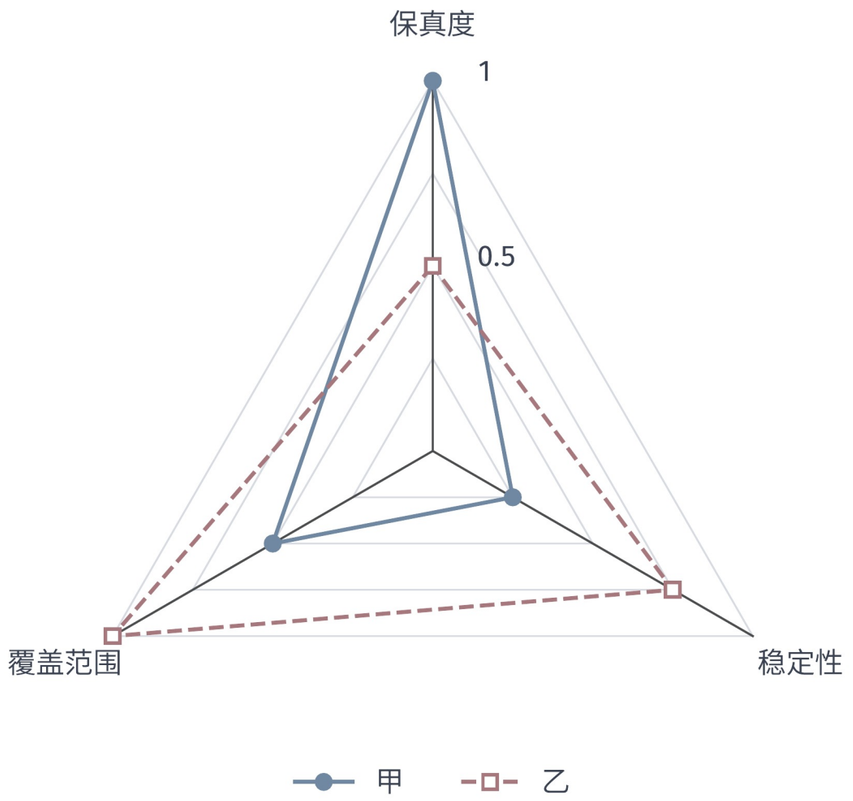


当前图注：两套构造方案纳入的检查项数。三个维度各预设四项，甲纳入4、2、1项，乙纳入2、4、3项，径向值为项数除以4，线型和标记区分方案。真实检查需预先说明内容与难度；图中面积不合成质量评分，另两项人员与使用评价仍须执行。

# 078 可解释性

fig:trust-actionable-recourse | 当前与提交前不同

提交前 · fbb26aec

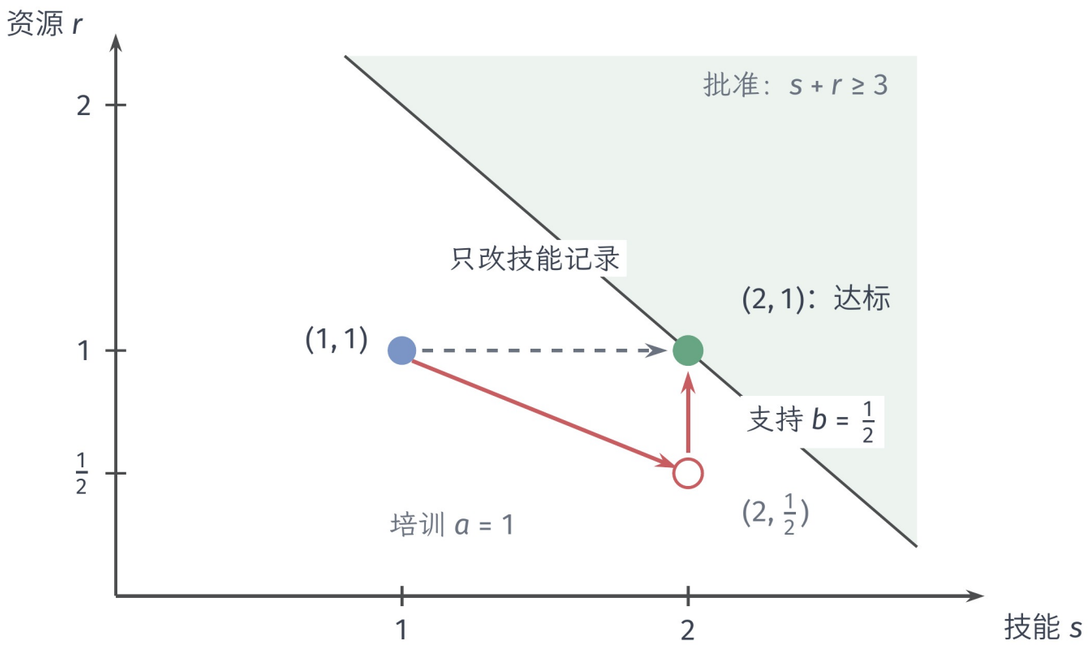


$s' = 1 + a, \qquad r' = 1 - a/2 + b$

当前 · 7dd5e395

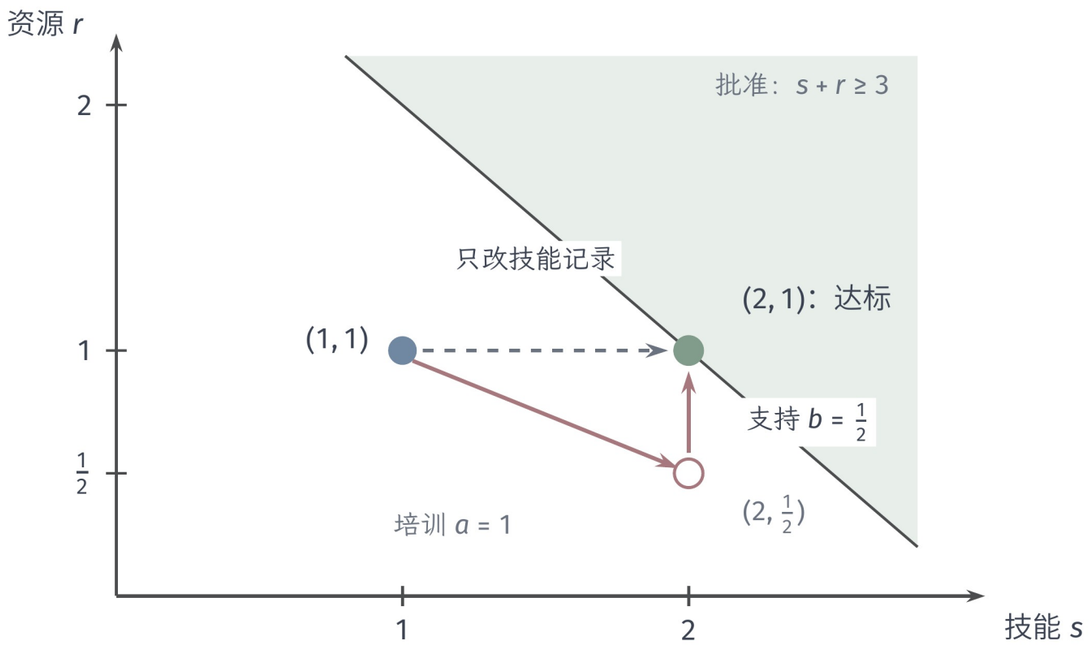


$s' = 1 + a, \qquad r' = 1 - a/2 + b$

当前图注：示例~ex:interpretability-causal-recourse的约束补救组合。虚线表示只改技能记录；培训a=1实际先到(2,1/2)，支持b=1/2再到批准边界。仅培训且上限为1无法达标，组合成本2.5；预算为2时，成本下界证明允许集合中无可行方案。

图片保持原比例；同框适配，仅用于比较独立图。完整图注与源路径见网页及清单。

# 079 隐私保护

fig:trust-membership-inference | 当前与提交前不同

## 提交前 · fbb26aec

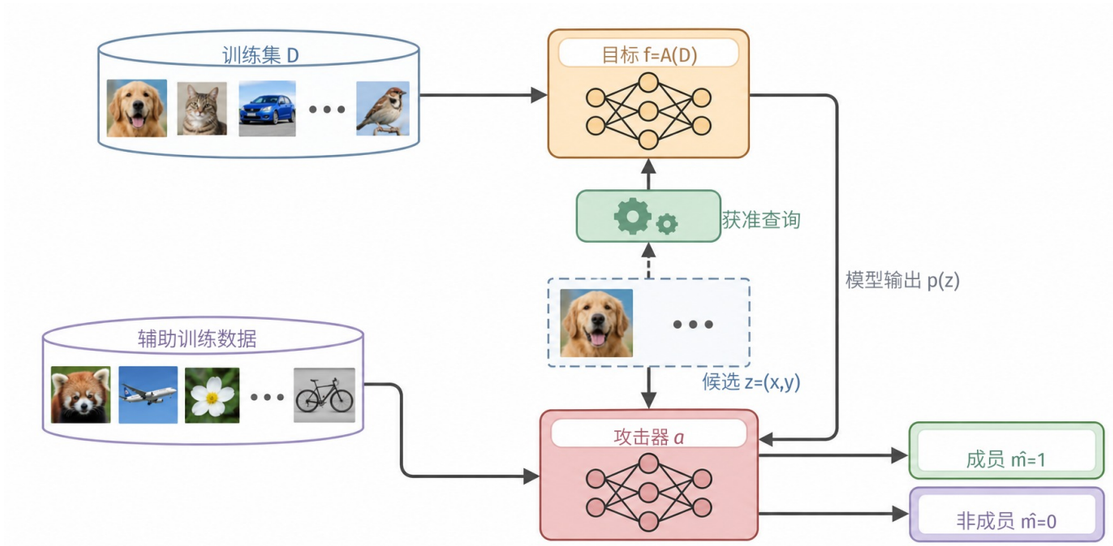


## 当前 · 7dd5e395

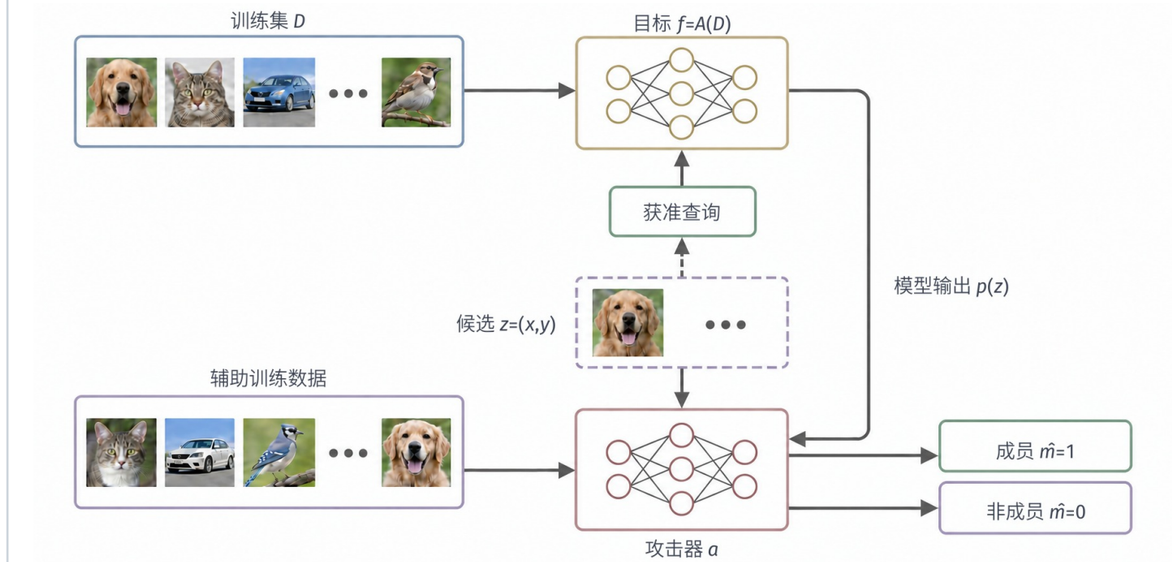


当前图注：成员推断的受控审计流程。候选成员与非成员按同一分布抽取，目标模型仅用D训练；记录z=( x,y)经获准查询取得输出。图标个数表示分组，不表示成员先验；已知真实y时可以计算损失。攻击器用辅助成员数据训练，在验证数据上定阈值，并在独立审计集统计成员命中率和非成员误报率。目标成员真值用于核验，不能作为攻击器输入。该流程不承诺攻击成功，还须报告权限、查询预算与成员先验。

图片保持原比例；同框适配，仅用于比较独立图。完整图注与源路径见网页及清单。

# 080　隐私保护

fig:dp-sgd-update | 当前与提交前不同

## 提交前 · fbb26aec

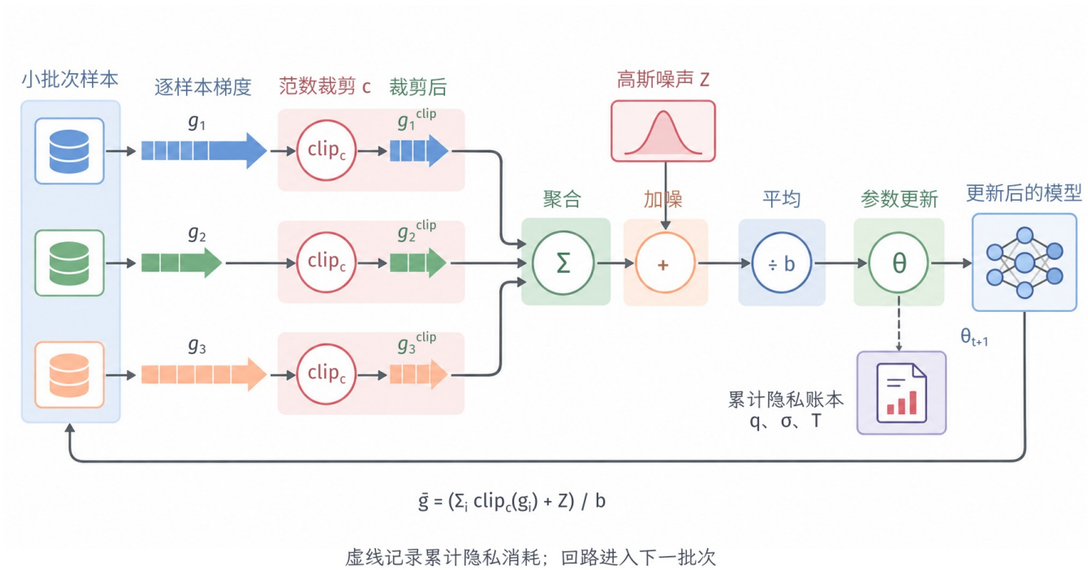


## 当前 · 7dd5e395

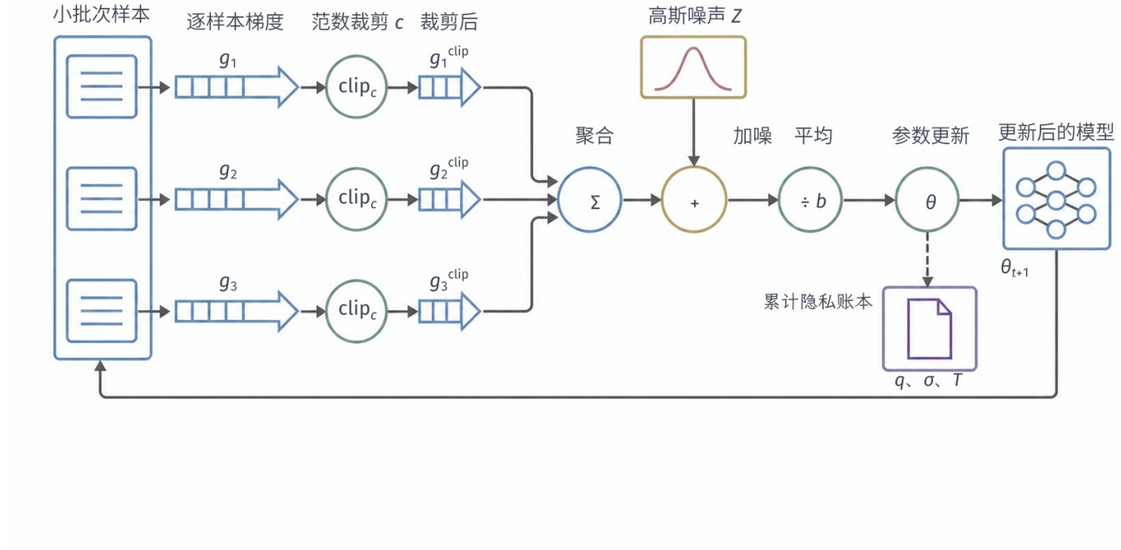


当前图注：DP-SGD的一次更新。分别计算批次梯度 g_i，按c取clip_c( g_i)= g_i\1,c/ g_i_2\，随后求和、加入高斯噪声 Z、除以b并更新。账本结合抽样率q、噪声尺度、步数T等累计消耗，分析必须对应保护单位、邻接关系和抽样约定。向量长度及高斯曲线只示意机制。

# 081　隐私保护

fig:pate-private-teachers | 当前与提交前不同

## 提交前 · fbb26aec

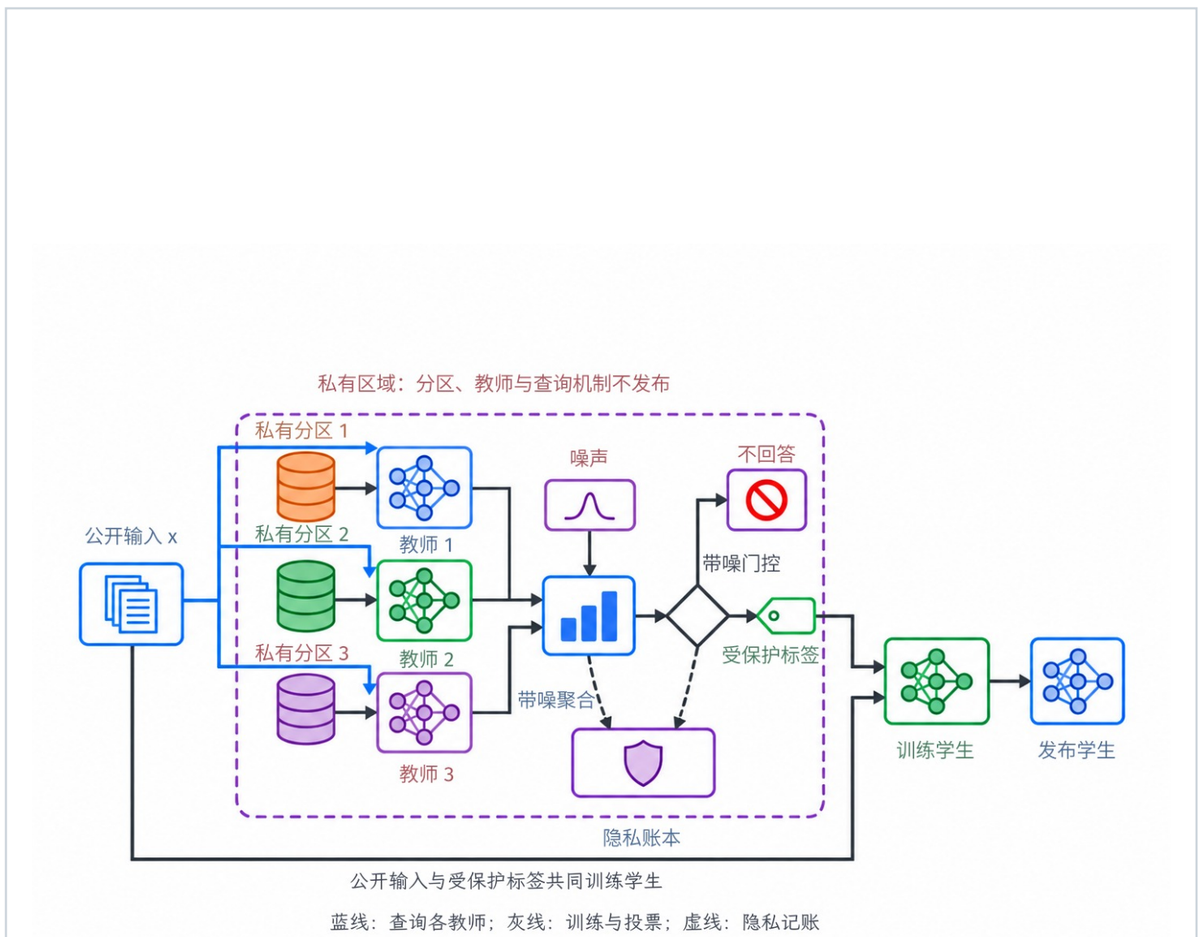


公开输入与受保护标签共同训练学生

蓝线：查询各教师；灰线：训练与投票；虚线：隐私记账

## 当前 · 7dd5e395

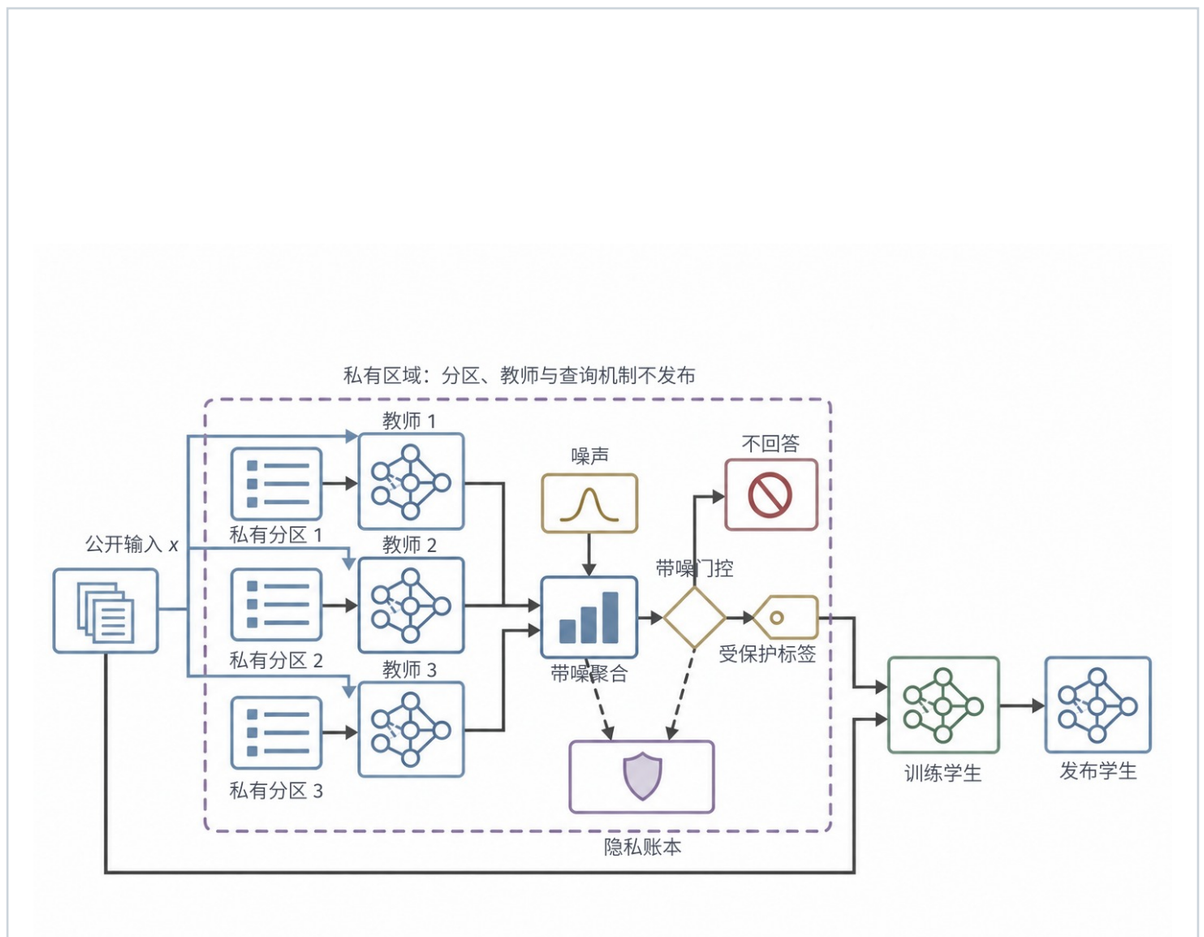


当前图注：PATE的信息流。各教师用互不重叠的私有分区训练并保持不发布，非敏感公开输入取得各教师投票。加噪聚合和带噪门控产生受保护标签，低共识可不回答；两项决定均计入查询隐私消耗。学生仅以公开输入和受保护标签训练后发布，不能接触私有样本或单个教师。蓝线为公开查询，灰线为训练与投票，虚线为隐私记账；条形表示投票机制，不是实测数值。

# 082　隐私保护

fig:trust-dp-neighbors | 当前与提交前不同

## 提交前 · fbb26aec

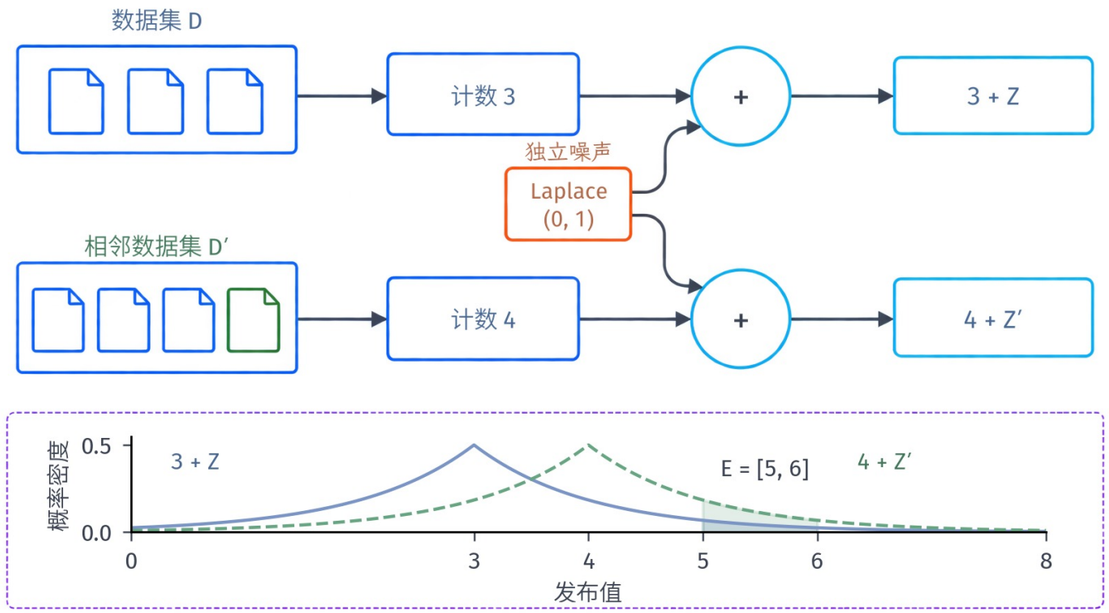


## 当前 · 7dd5e395

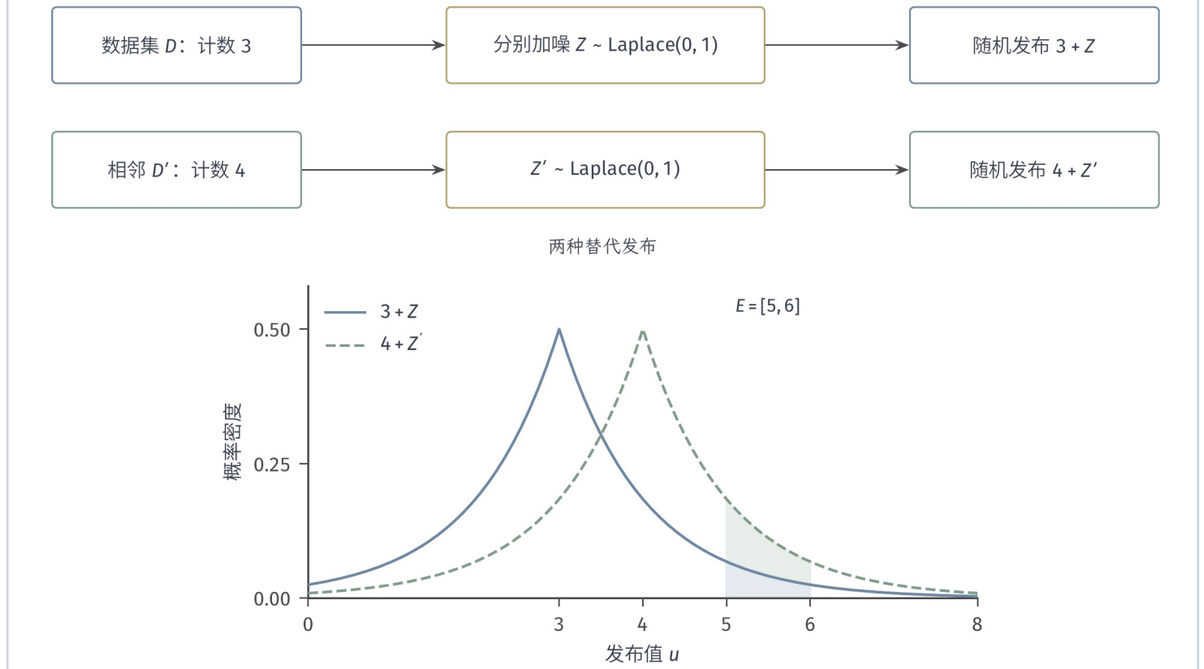


当前图注：相邻计数的随机发布。两数据集仅差新增一条记录，准确计数为3和4；各反事实机制都使用尺度1的拉普拉斯分布，故 F=1、=1、=0。两行是替代发布情形，不表示共同发布两次，也未规定联合耦合。每一行由准确计数经加噪得到随机发布，下方实线与虚线为解析密度，阴影比较同一事件E=[5,6]；横轴只画部分范围。一次输出的保护须对全部相邻数据和全部事件成立，曲线重叠只是示意。

# 083 隐私保护

fig:trust-privacy-deletion | 当前与提交前不同

## 提交前 · fbb26aec

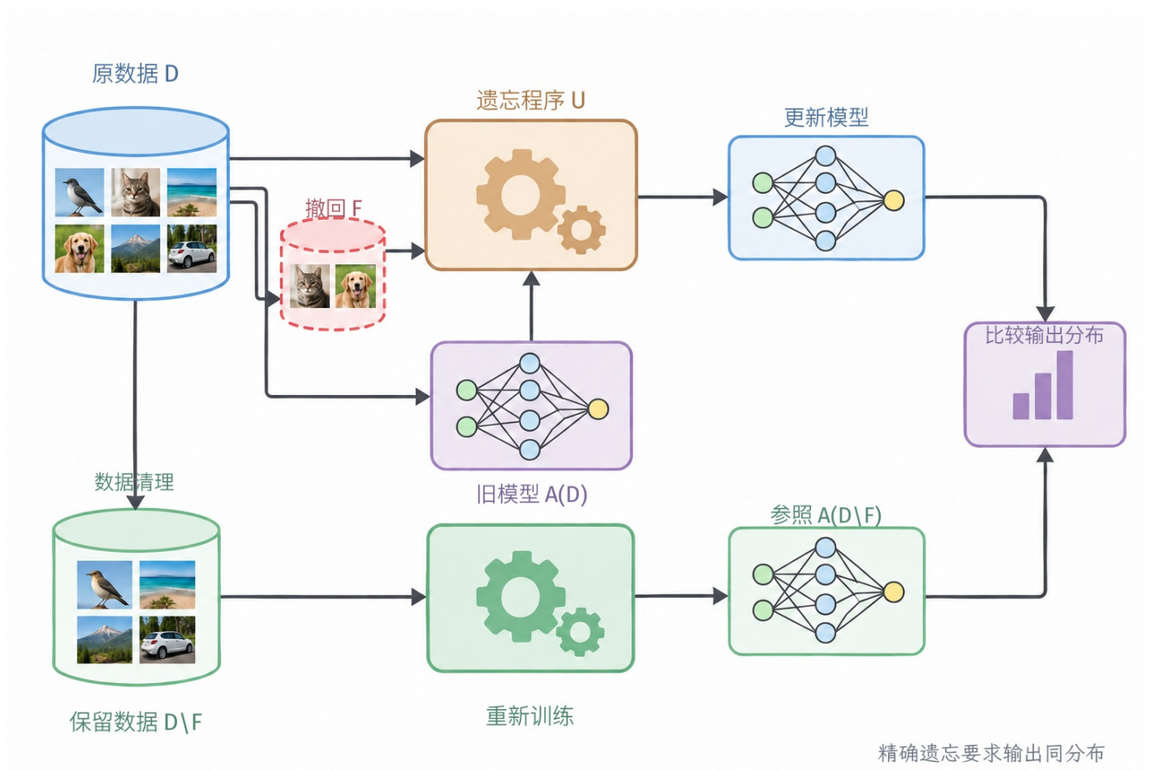


## 当前 · 7dd5e395

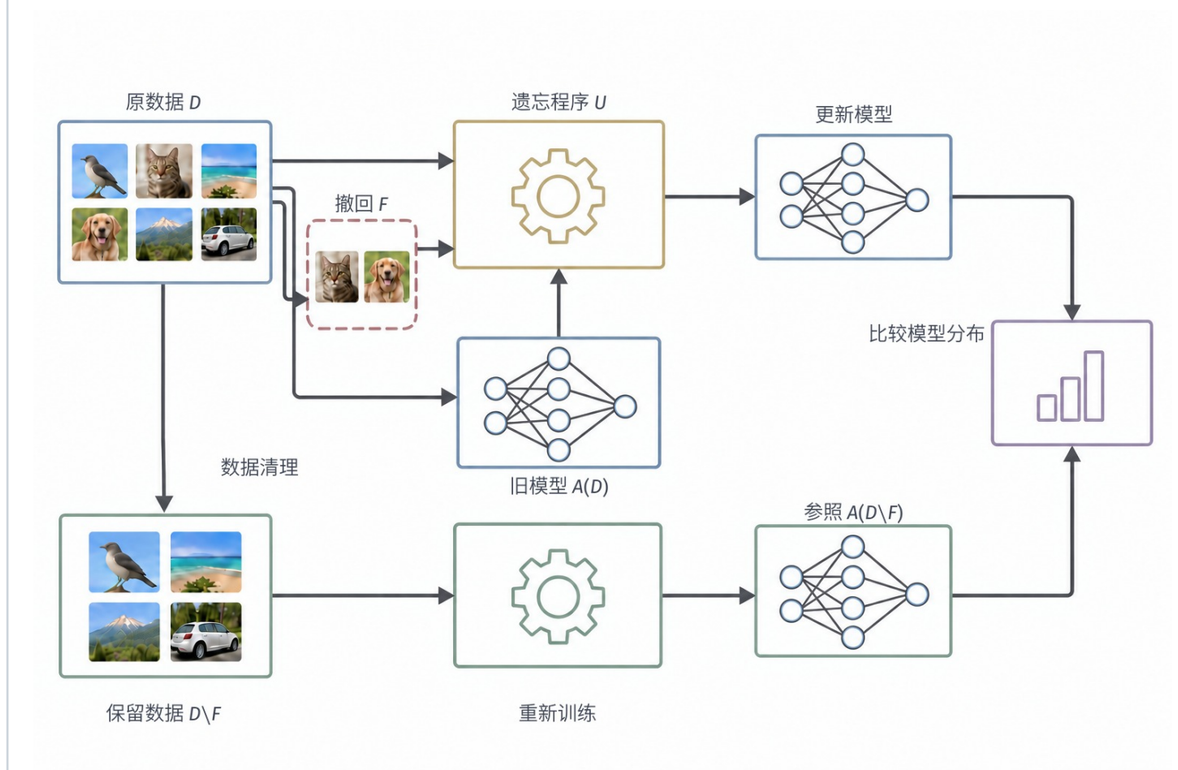


当前图注：数据清理与训练影响消除。删除记录得到D F，旧模型A(D)仍保持原状态；U另外读取旧模型、原数据和撤回集合进行更新。应比较更新结果与从未使用F的重训练模型分布：精确遗忘要求同分布，近似遗忘需指定距离或可区分性标准。

# 084 对抗安全

fig:backdoor-poisoning | 当前与提交前不同

提交前 · fbb26aec

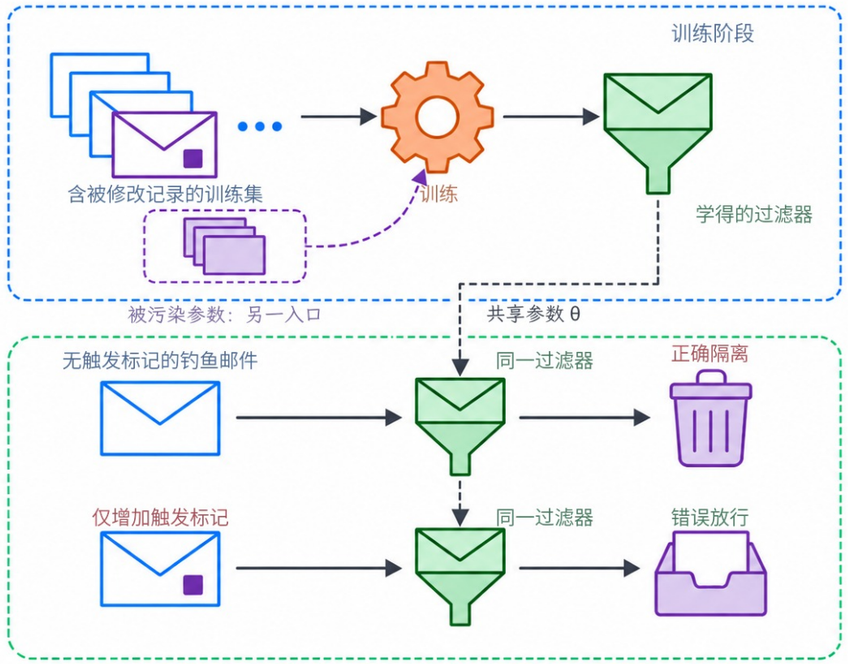


干净输入上的性能不能排除后门；此处仅示意条件性异常

当前 · 7dd5e395

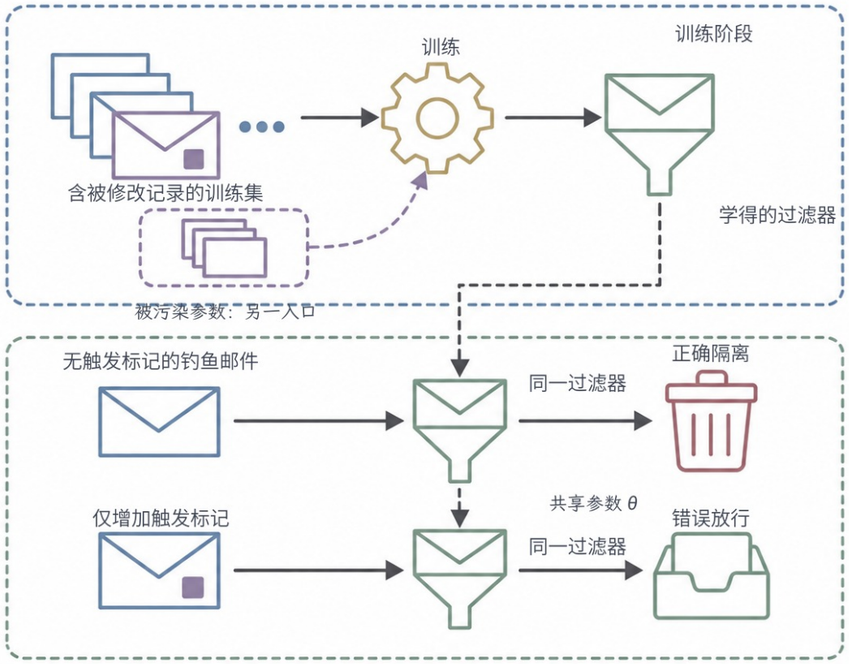


当前图注：投毒操作与后门触发分别位于训练和部署。污染记录或参数经训练入口影响过滤器；同一钓鱼邮件无标记时隔离，加触发标记后放行，两个过滤器图案为同一参数模型的两次调用。图中参数污染经训练接入只表示此处路径，并非所有后门都需数据投毒；图未给成功率。

# 085 对抗安全

fig:trust-threat-model-coordinates | 当前与提交前不同

## 提交前 · fbb26aec

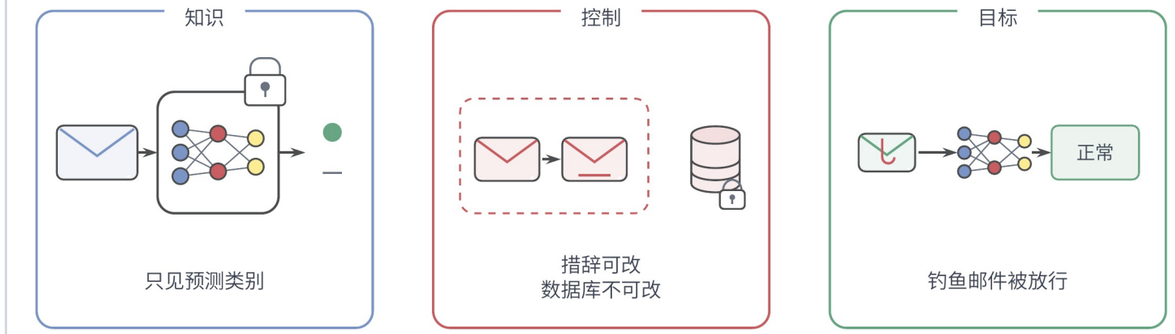


## 当前 · 7dd5e395

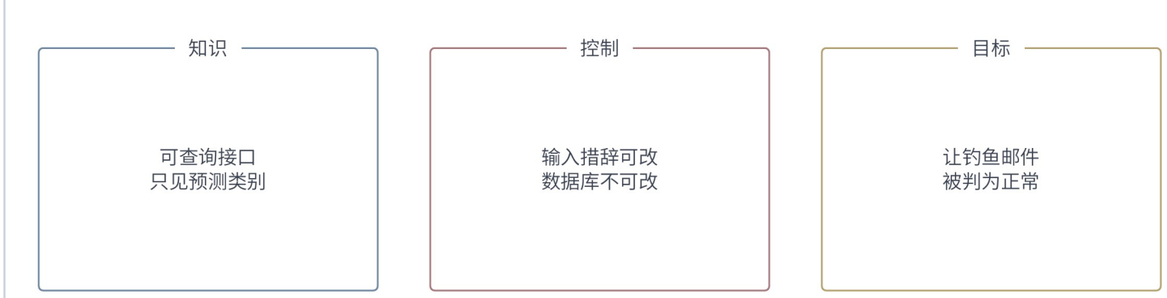


当前图注：一次教学威胁模型的压缩视图：仅返回预测类别，可在欺骗目的保持的前提下改写邮件，以钓鱼邮件判正常为成功事件。20次查询是预算而非实验结果。可见信息、可控对象和成功事件不能互推；完整记录还含资产、信任边界、时序、身份与串通范围，无适用取值的字段明确说明。

# 086 对抗安全

fig:trust-security-entrypoints | 当前与提交前不同

## 提交前 · fbb26aec

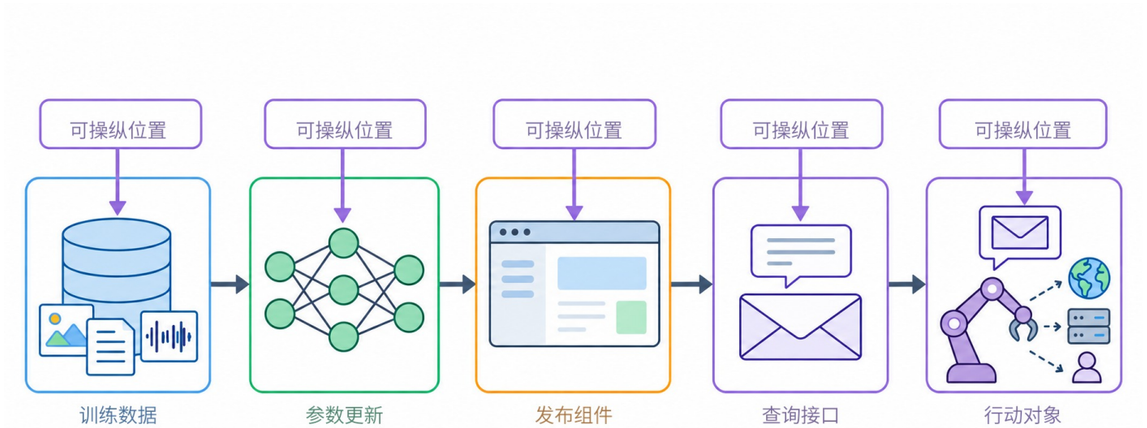


紫色路径表示攻击进入；不表示攻击必然成功

## 当前 · 7dd5e395

虚线：可操纵入口

当前图注：攻击入口按可操纵对象定位：记录内容、更新参数、发布组件、接口输入及查询、提案的行动对象。紫色箭头标控制位置，未表示攻击成功；灰色路径标系统阶段联系。同一攻击可经过多个入口，知识、预算和损害目标仍需组合声明。

# 087 对抗安全

fig:trust-adversarial-perturbation | 当前与提交前不同

提交前 · fbb26aec

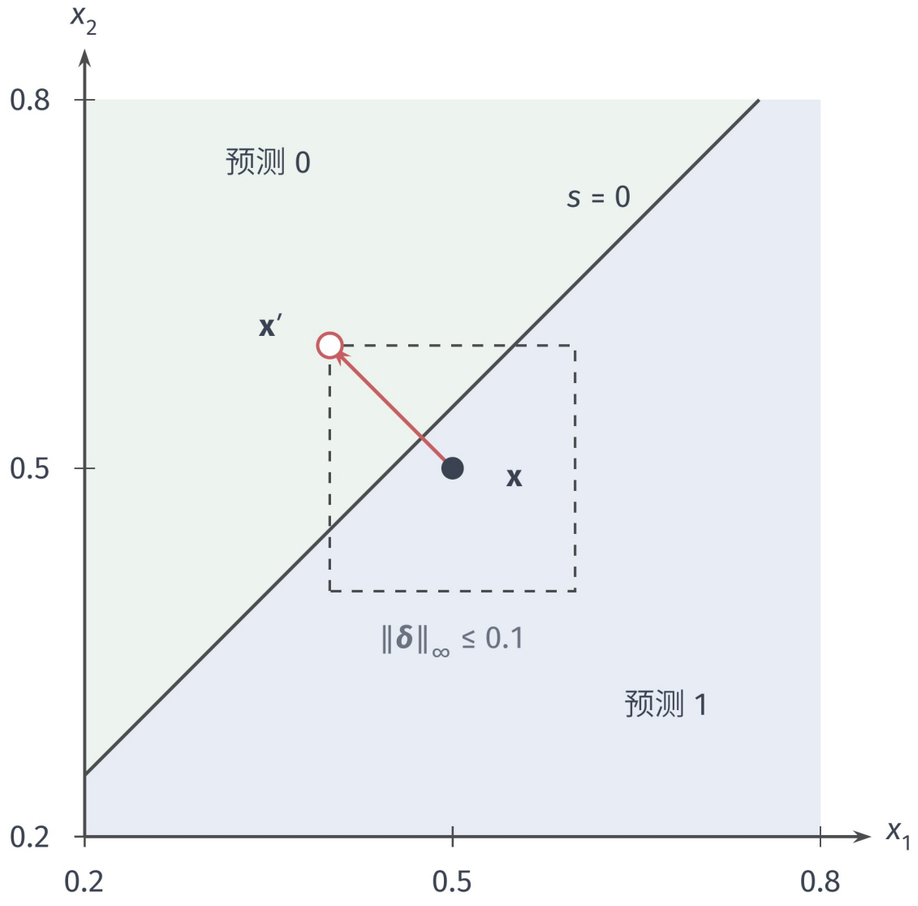


当前 · 7dd5e395

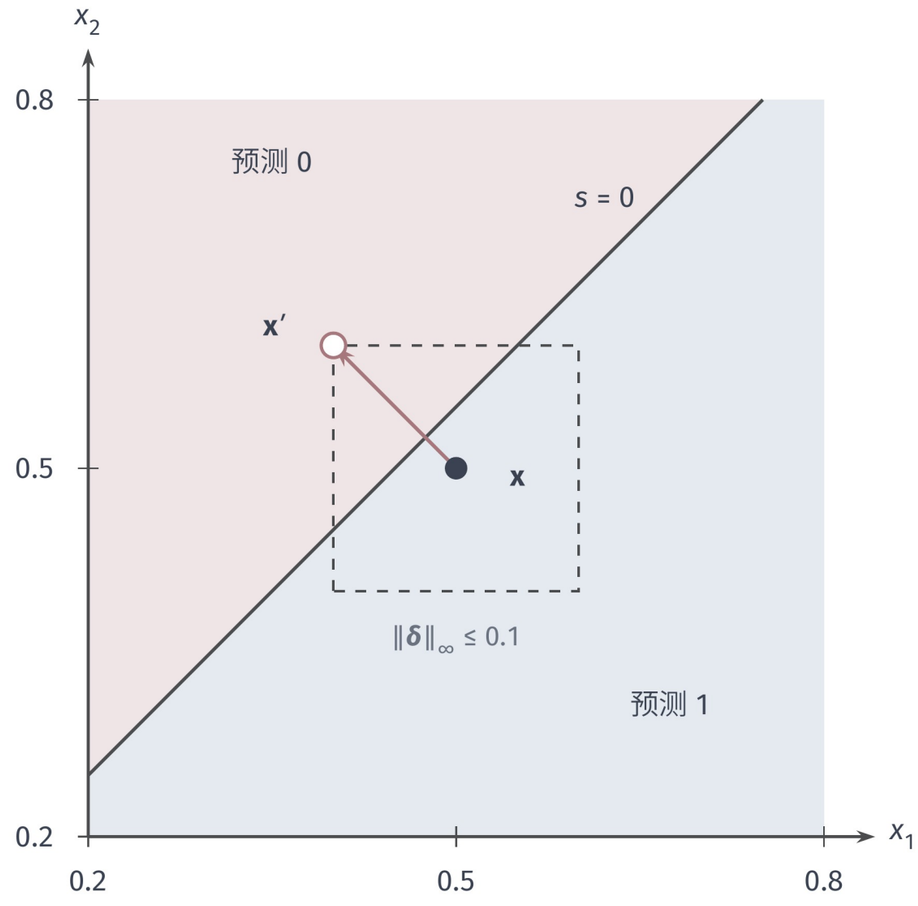


当前图注：教学线性评分器中的预算内候选。(0.5,0.5)得0.05，(0.4,0.6)用扰动(-0.1,0.1)、无穷范数0.1得到-0.15。浅色为模型预测区，实线为s=0，虚线方形为允许集合。翻转只对应模型；邻域真实标签仍为1且候选合法时，才是有效攻击反例。单步构造不保证任意模型的攻击成功。

图片保持原比例；同框适配，仅用于比较独立图。完整图注与源路径见网页及清单。

# 088 对抗安全

fig:trust-prompt-injection-boundary | 当前与提交前不同

## 提交前 · fbb26aec

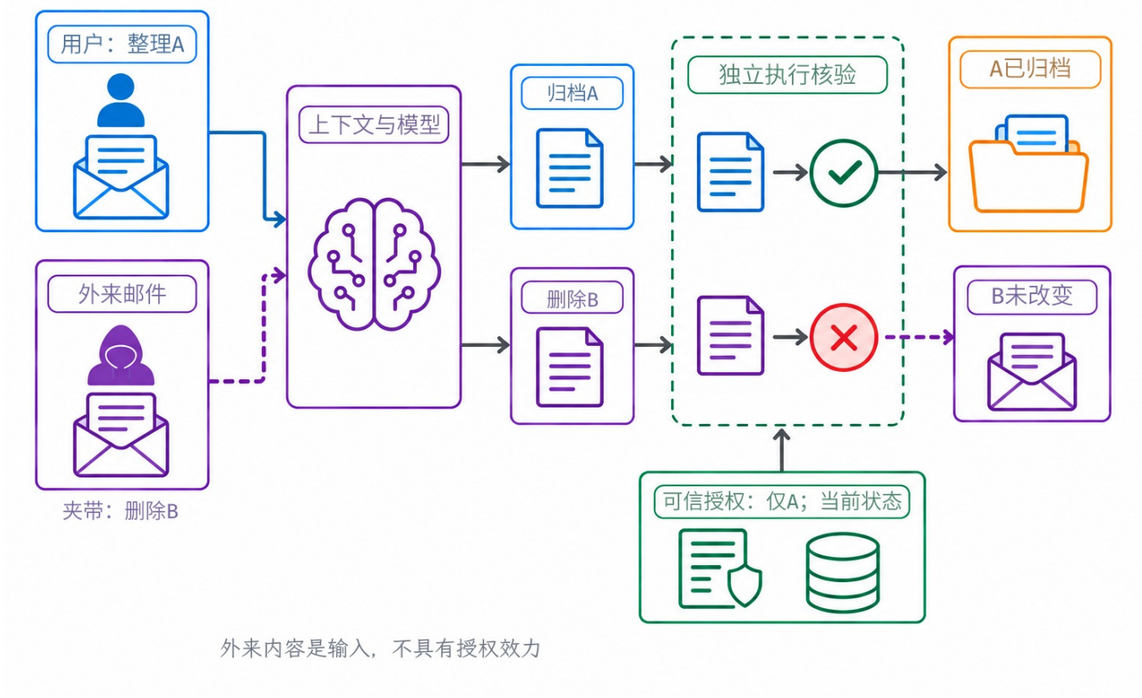


## 当前 · 7dd5e395

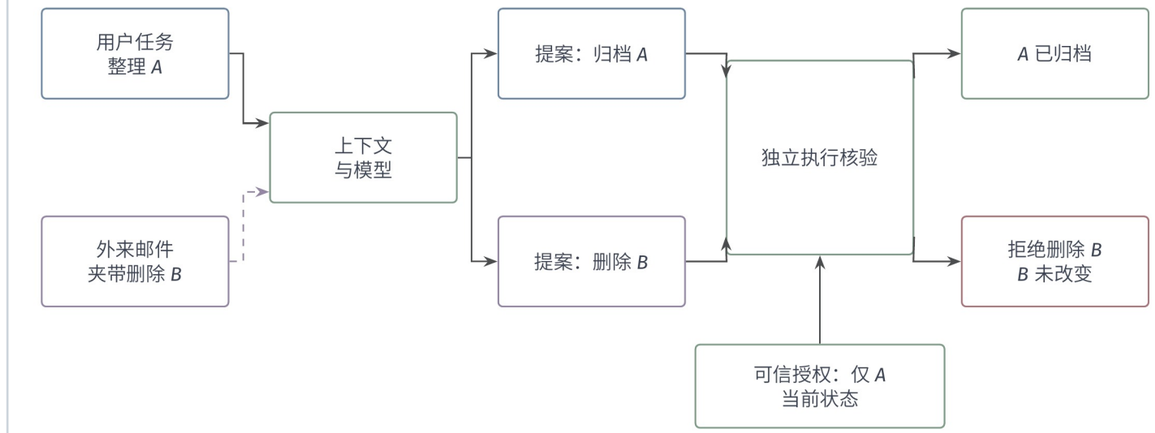


当前图注：第三方邮件影响动作提案的教学情景。用户只授权邮件A，外来内容用虚线夹带删除B要求，模型可能提出归档A及删除B。执行端以可信授权和状态独立检查，允许A而拒绝B，故B不变。这说明防护职责，实际仍需检查旁路、状态变化与损害。

图片保持原比例；同框适配，仅用于比较独立图。完整图注与源路径见网页及清单。

# 089 对抗安全

fig:trust-defense-in-depth | 当前与提交前不同

提交前 · fbb26aec

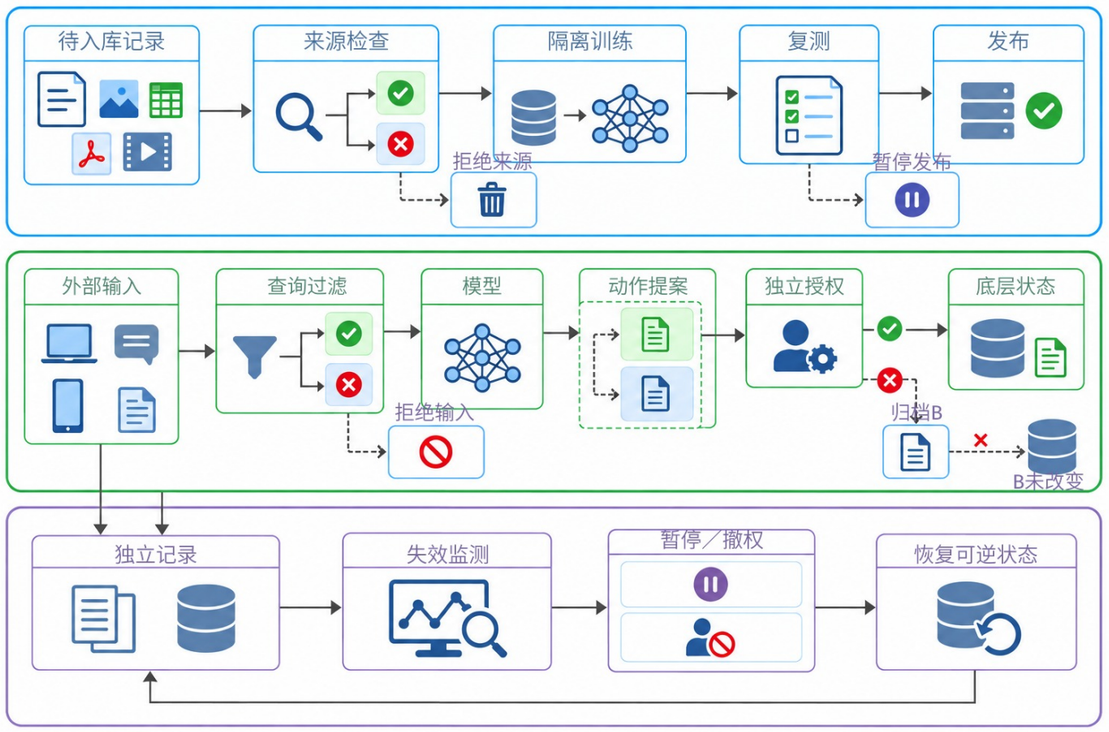


当前 · 7dd5e395

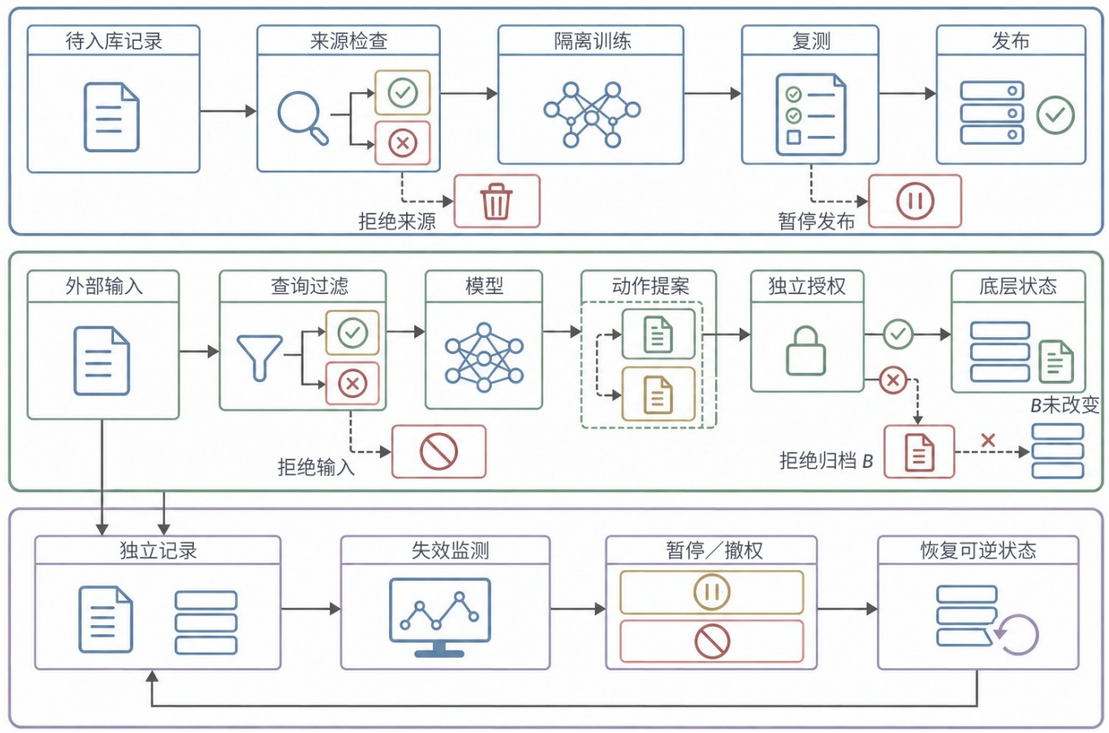


当前图注：纵深防御在训练与运行路径上的分工。未授权来源止于准入，异常候选模型暂不发布，但来源通过不证明内容无污染。合法格式的外部注入可到模型并提出归档B，独立授权拒绝越权对象后B不变。监测用独立记录和底层状态，失效后暂停、撤权及恢复可逆状态；外发信息不能据此收回。阻断依赖相应检查触发，未保证全部攻击可发现，也未假定各层失效独立。

图片保持原比例；同框适配，仅用于比较独立图。完整图注与源路径见网页及清单。