002 引言

fig:data-split-uses | 恢复旧设计，保留色阶并修正文字排版

提交前的原设计 · fbb26aec

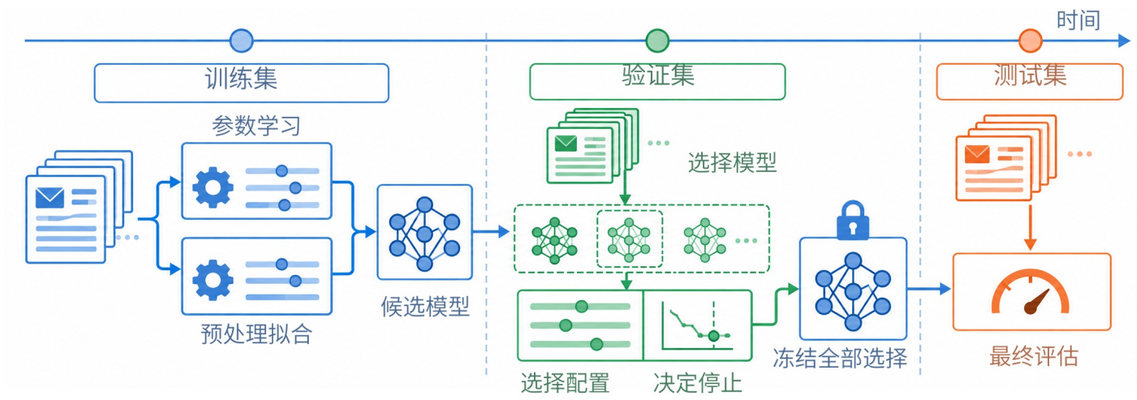

本次恢复版

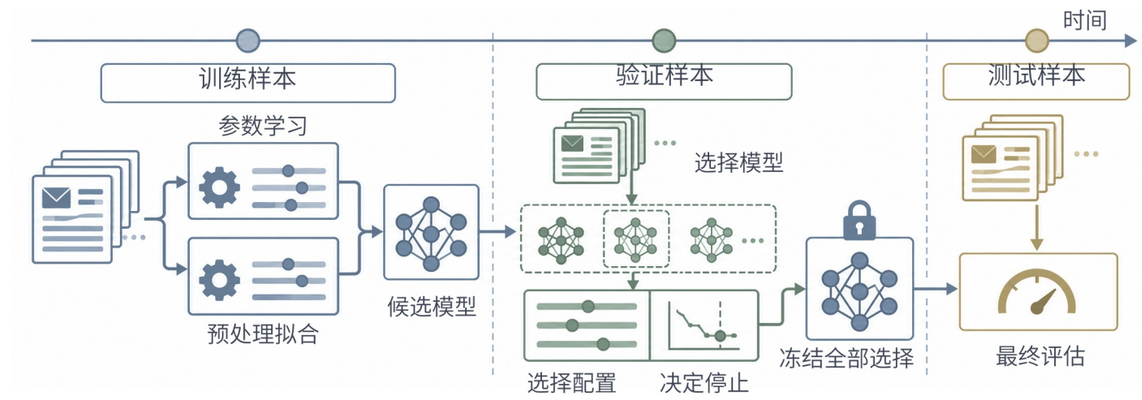

005　模型简介

fig:models-discriminative-generative | 恢复旧设计，保留色阶并修正文字排版

提交前的原设计 · fbb26aec

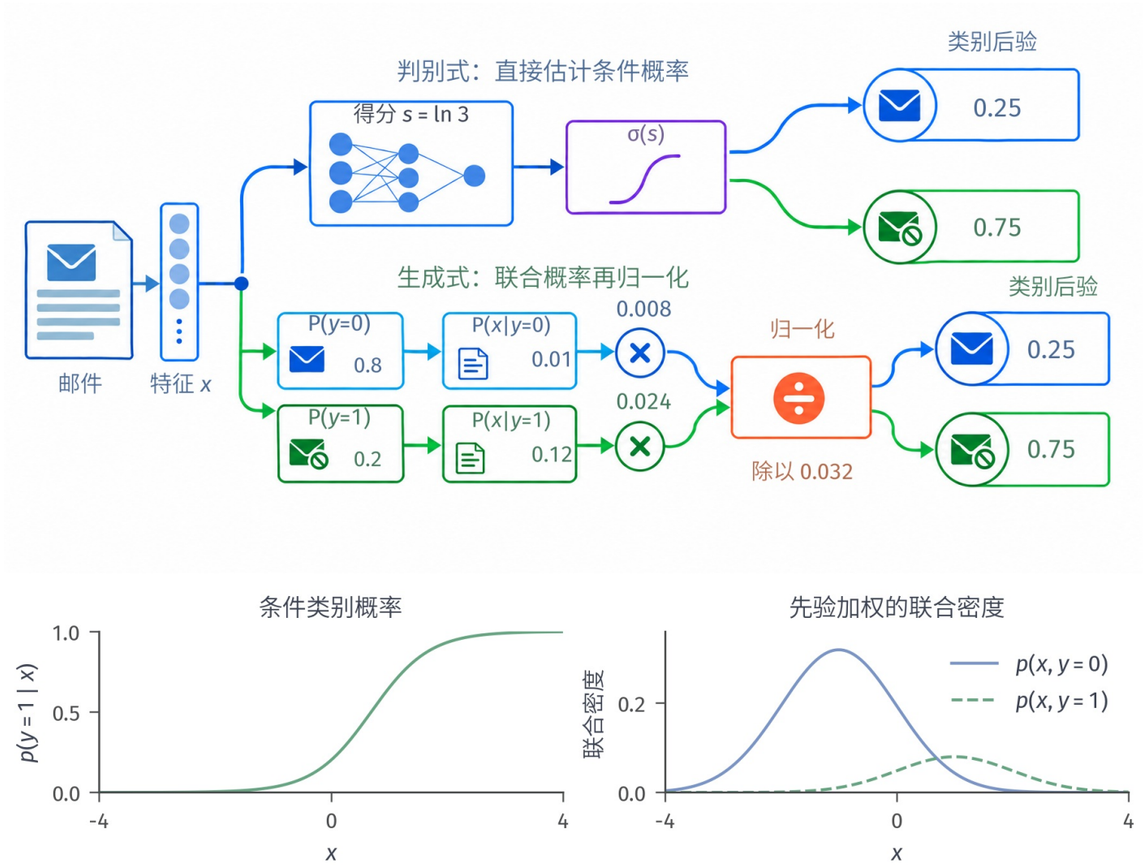

本次恢复版

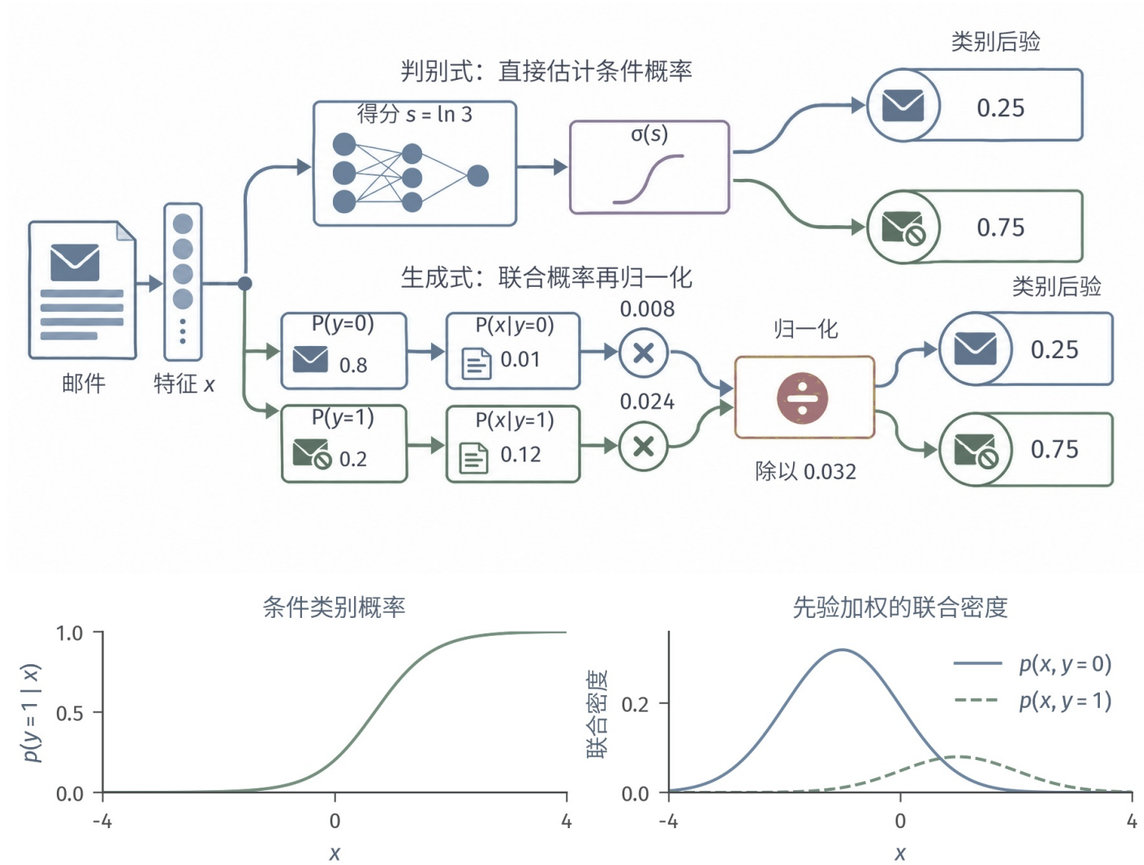

010　范式简介

fig:supervised-mnist-process | 恢复旧设计，保留色阶并修正文字排版

提交前的原设计 · fbb26aec

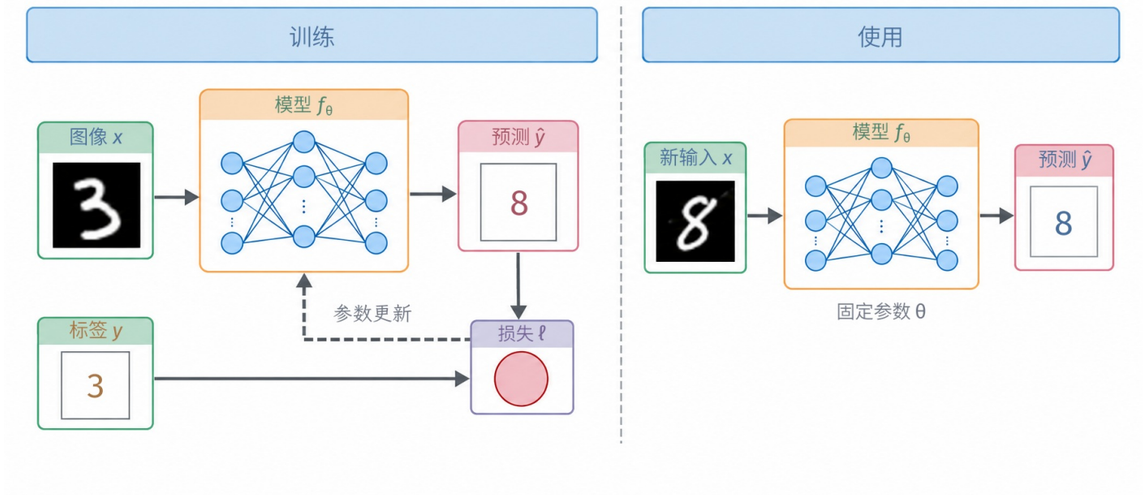

本次恢复版

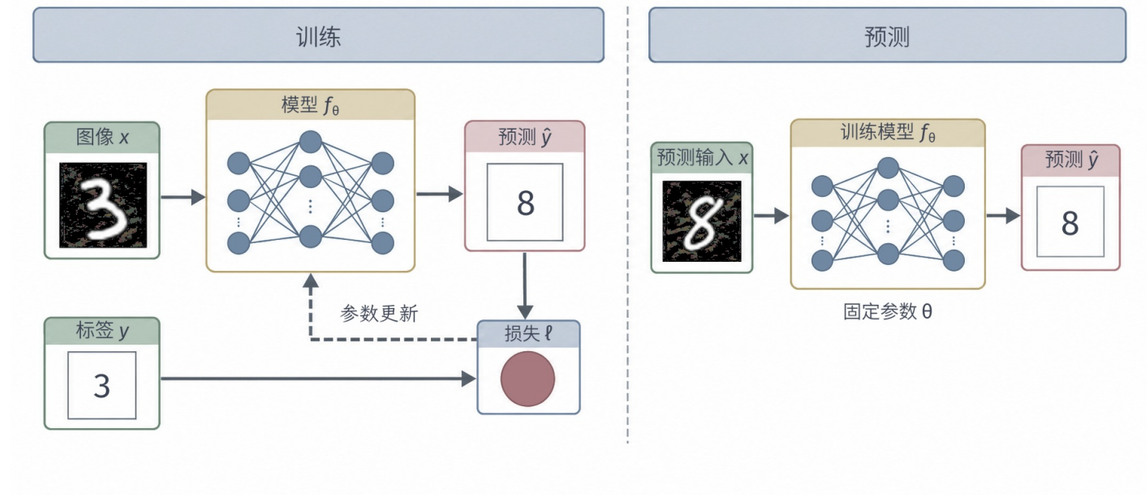

011　范式简介

fig:unsupervised-topic-process | 恢复旧设计，保留色阶并修正文字排版

提交前的原设计 · fbb26aec

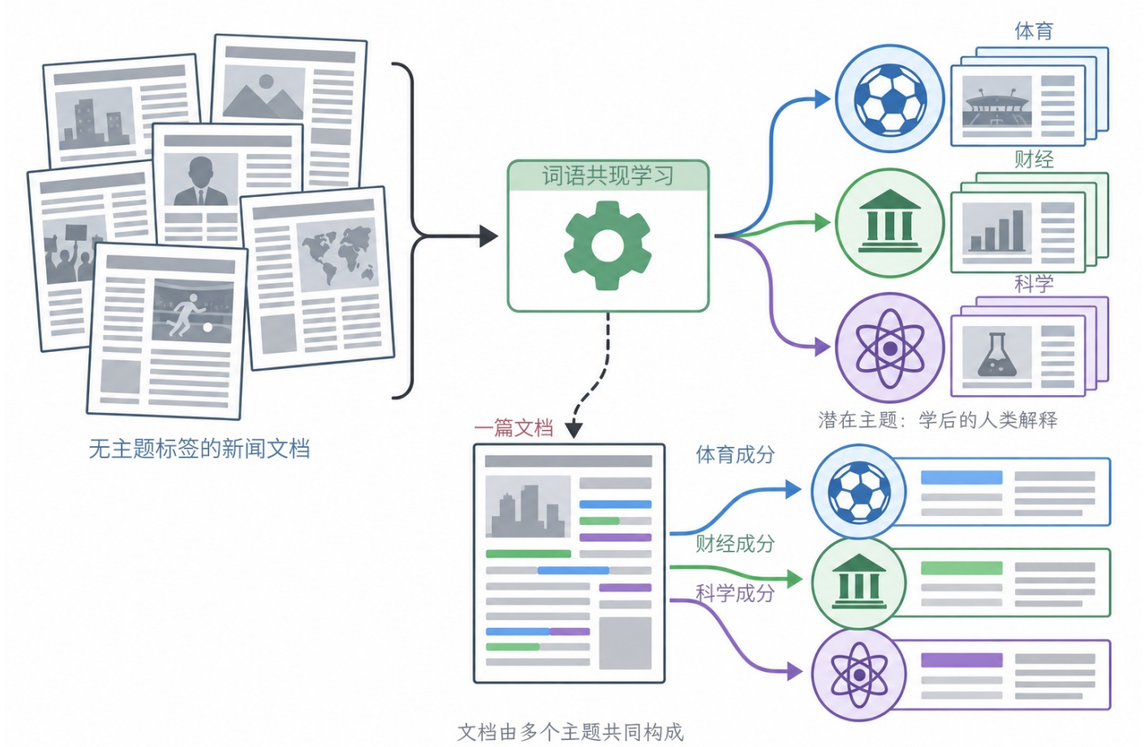

本次恢复版

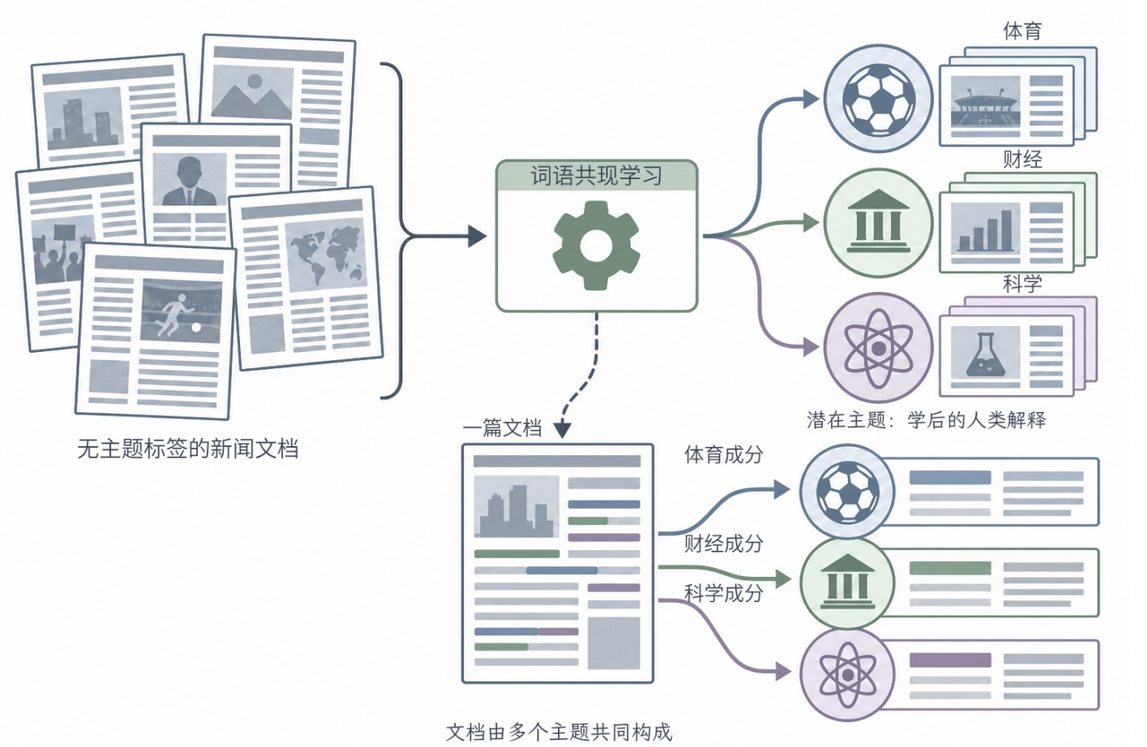

012　范式简介

fig:reinforcement-atari-process | 恢复旧设计，保留色阶并修正文字排版

提交前的原设计 · fbb26aec

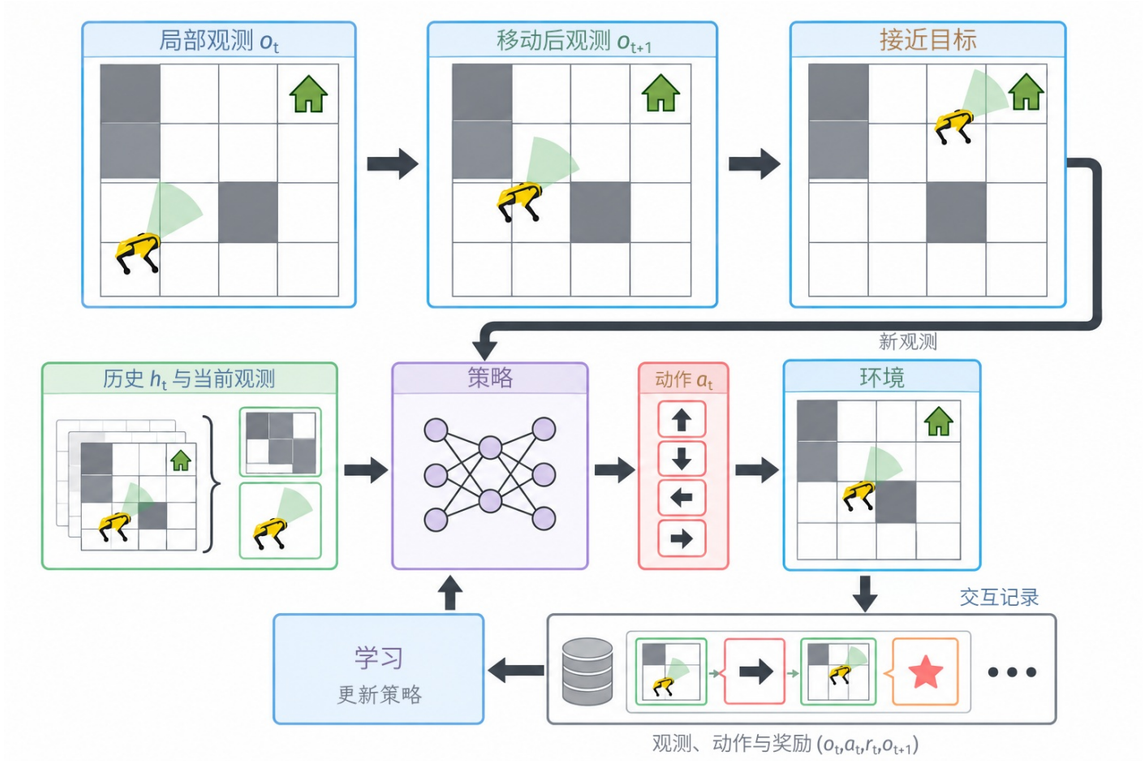

本次恢复版

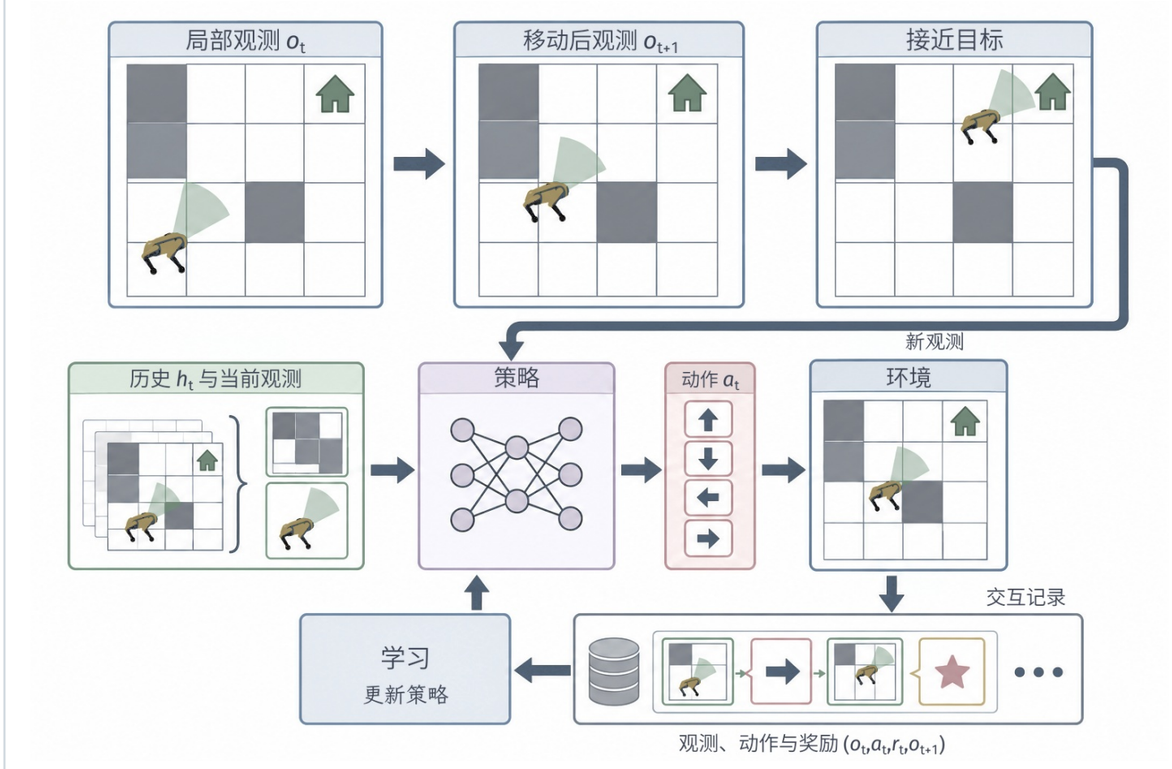

沿用原对比编号；图片等比例适配对比框，实际书页尺寸以卷三 PDF 为准。

013　范式简介

fig:semi-supervised-image-process | 恢复旧设计，保留色阶并修正文字排版

提交前的原设计 · fbb26aec

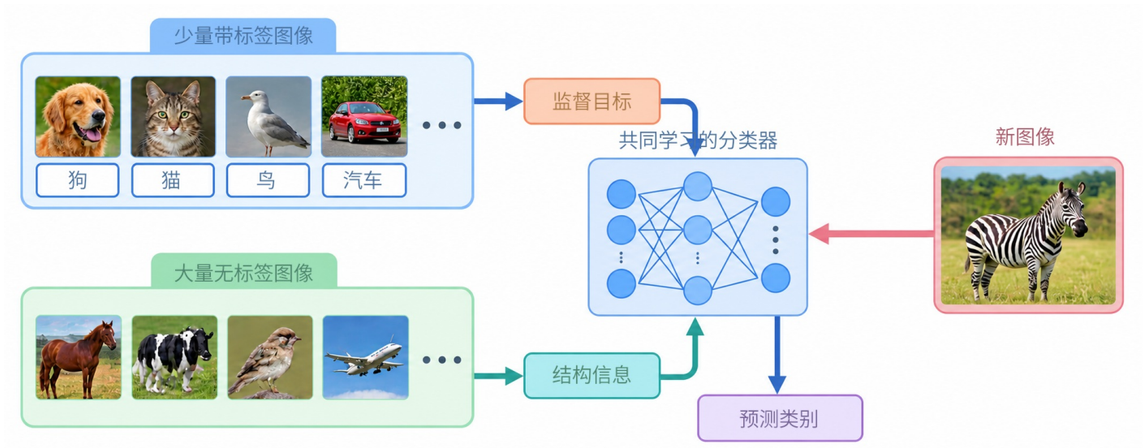

本次恢复版

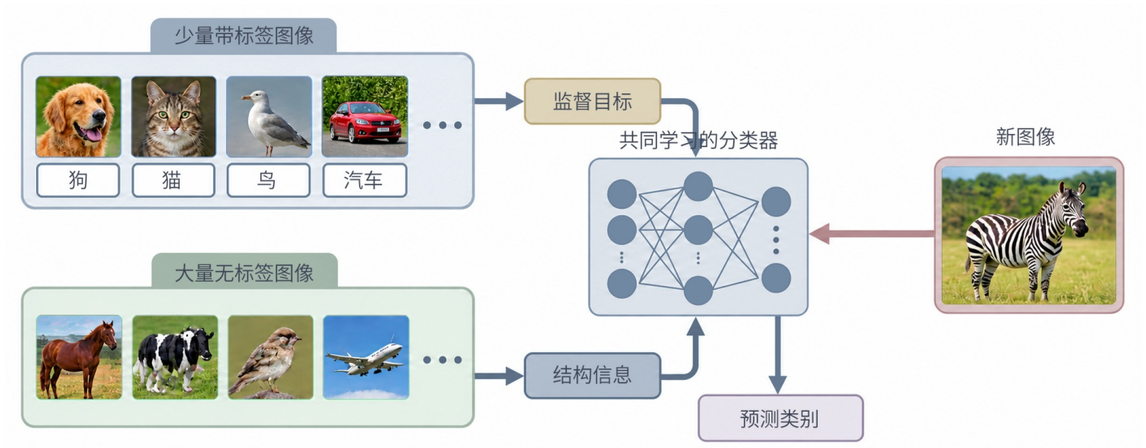

014　范式简介

fig:self-supervised-masked-process | 恢复旧设计，保留色阶并修正文字排版

提交前的原设计 · fbb26aec

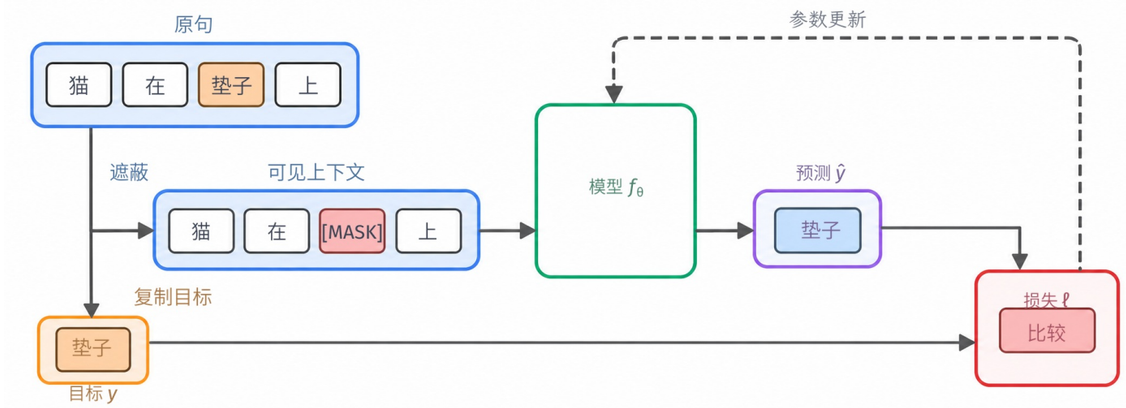

本次恢复版

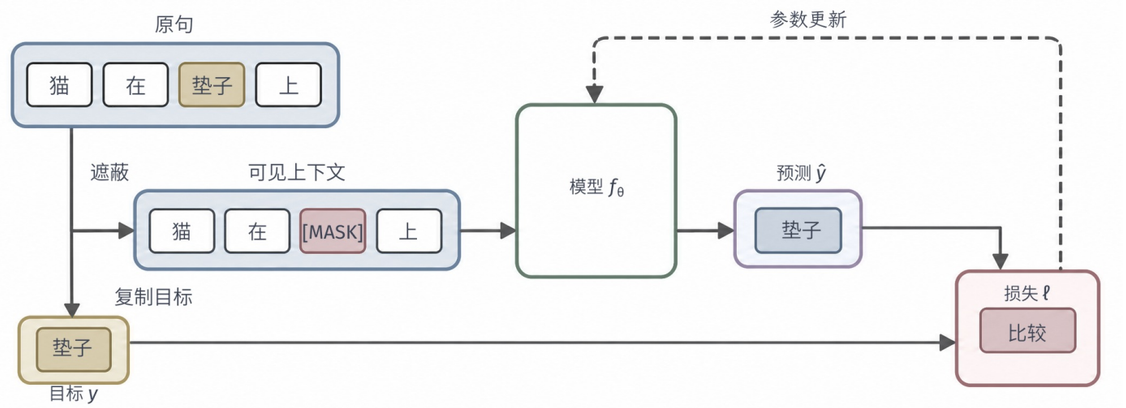

沿用原对比编号；图片等比例适配对比框，实际书页尺寸以卷三 PDF 为准。

015　范式简介

fig:weak-supervision-process | 恢复旧设计，保留色阶并修正文字排版

提交前的原设计 · fbb26aec

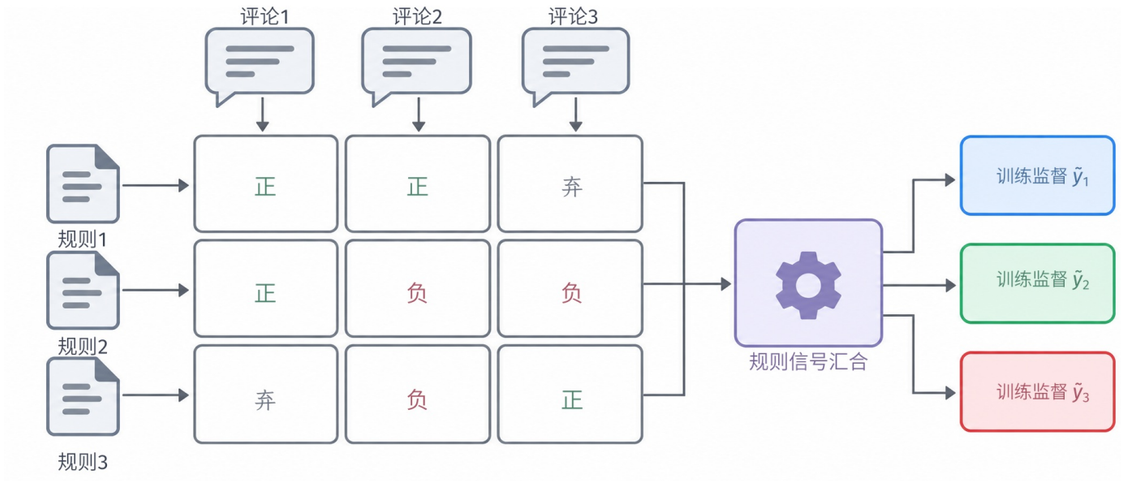

本次恢复版

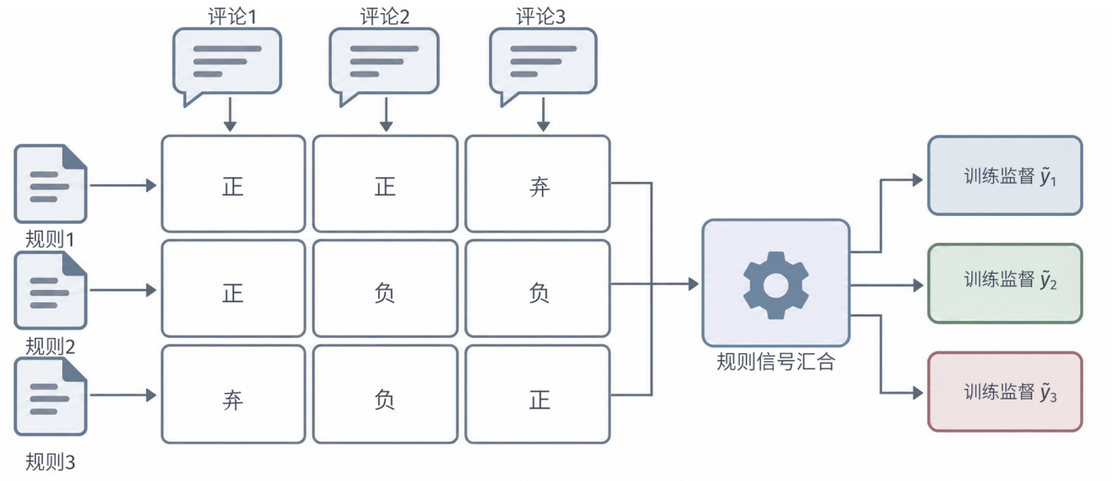

沿用原对比编号；图片等比例适配对比框，实际书页尺寸以卷三 PDF 为准。

016　范式简介

fig:contrastive-learning-process | 恢复旧设计，保留色阶并修正文字排版

提交前的原设计 · fbb26aec

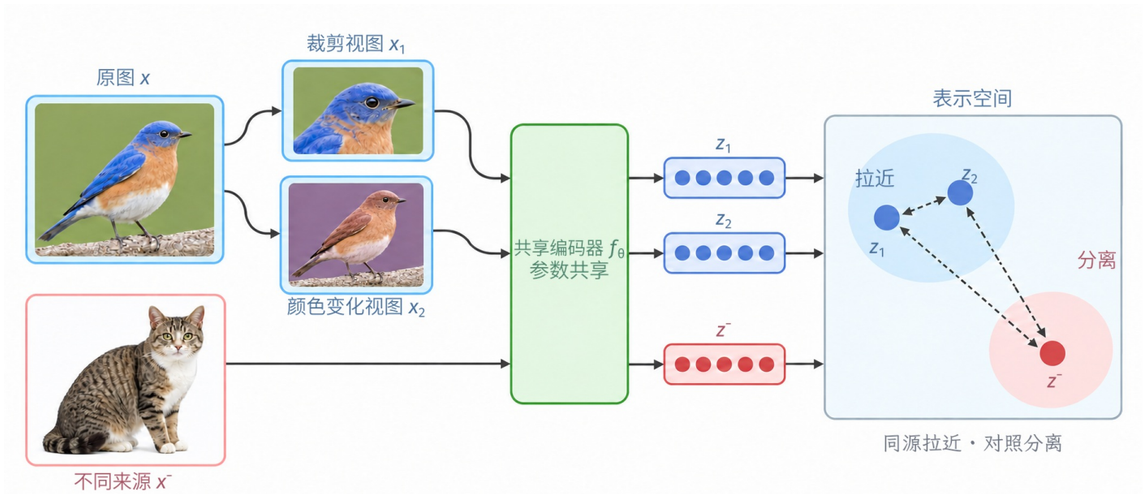

本次恢复版

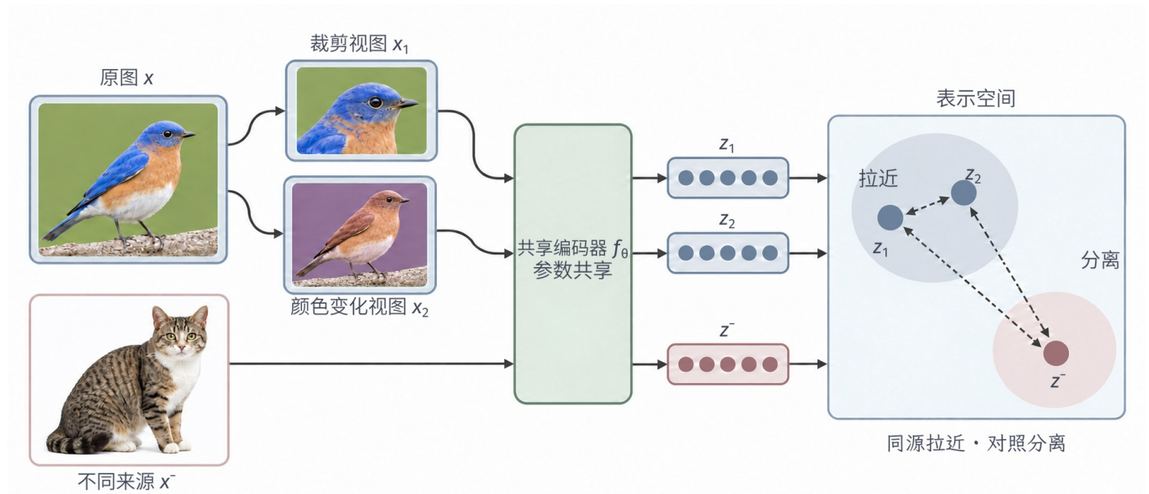

沿用原对比编号；图片等比例适配对比框，实际书页尺寸以卷三 PDF 为准。

017　范式简介

fig:active-learning-loop | 恢复旧设计，保留色阶并修正文字排版

提交前的原设计 · fbb26aec

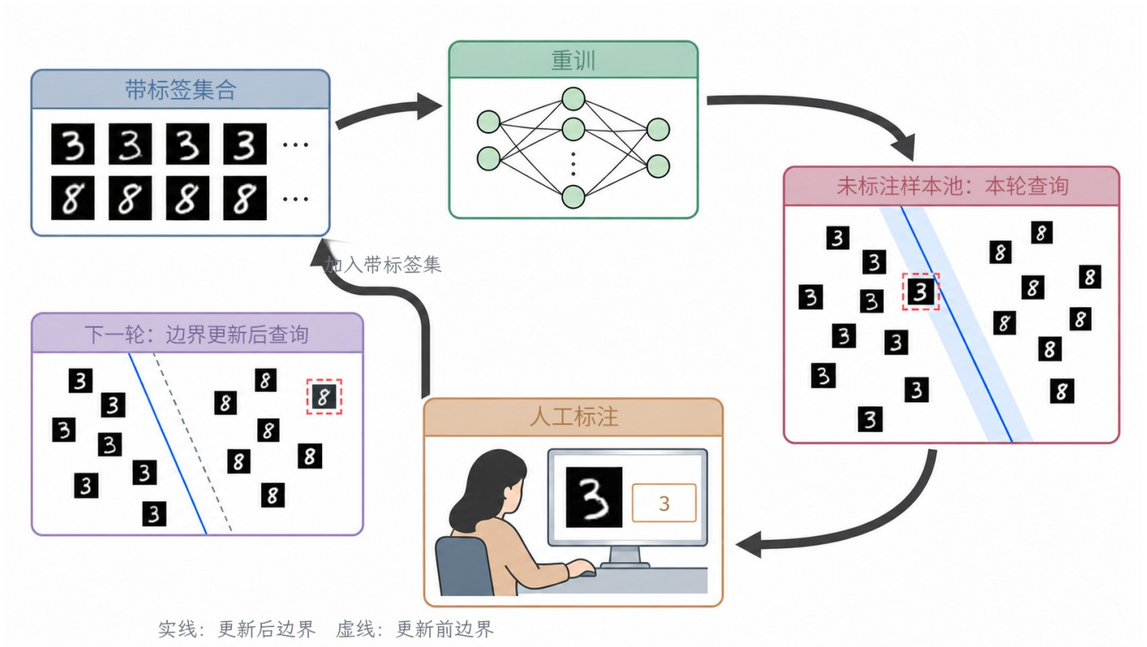

本次恢复版

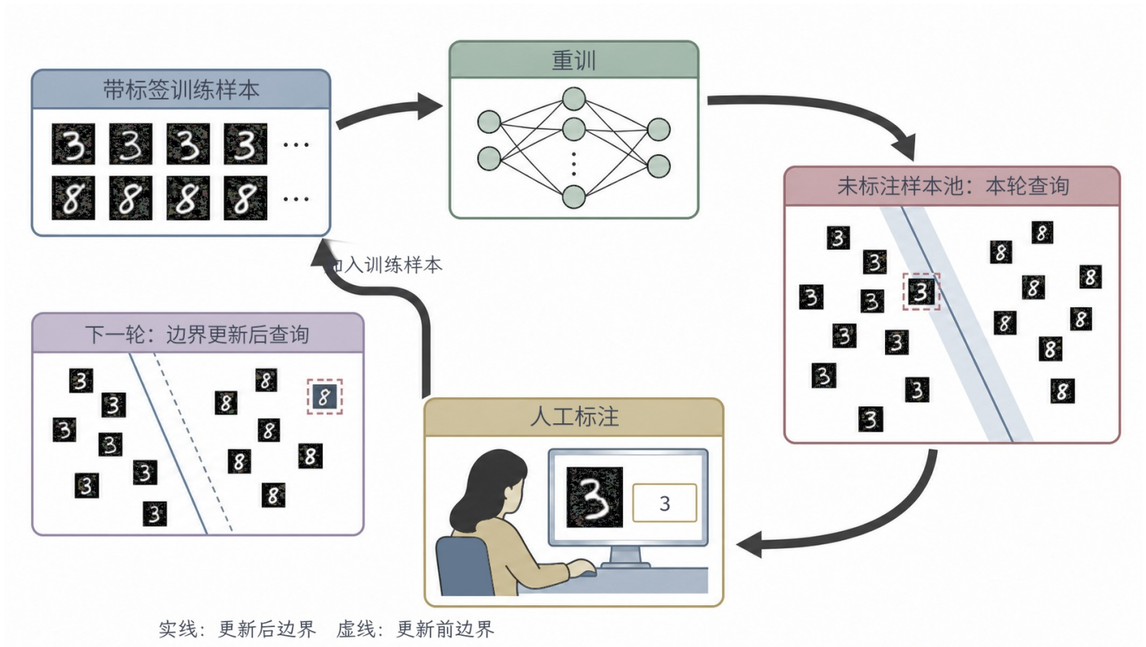

018　范式简介

fig:continual-learning-timeline | 恢复旧设计，保留色阶并修正文字排版

提交前的原设计 · fbb26aec

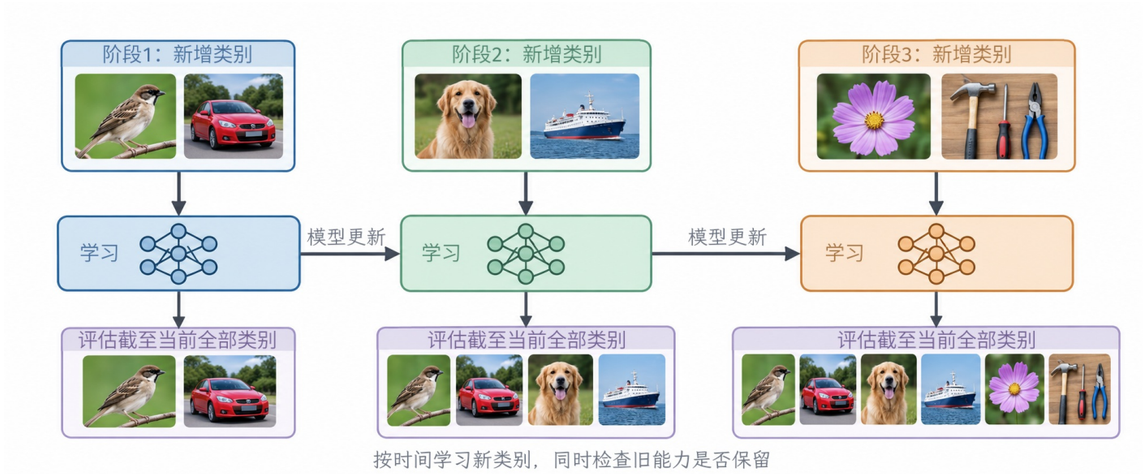

本次恢复版

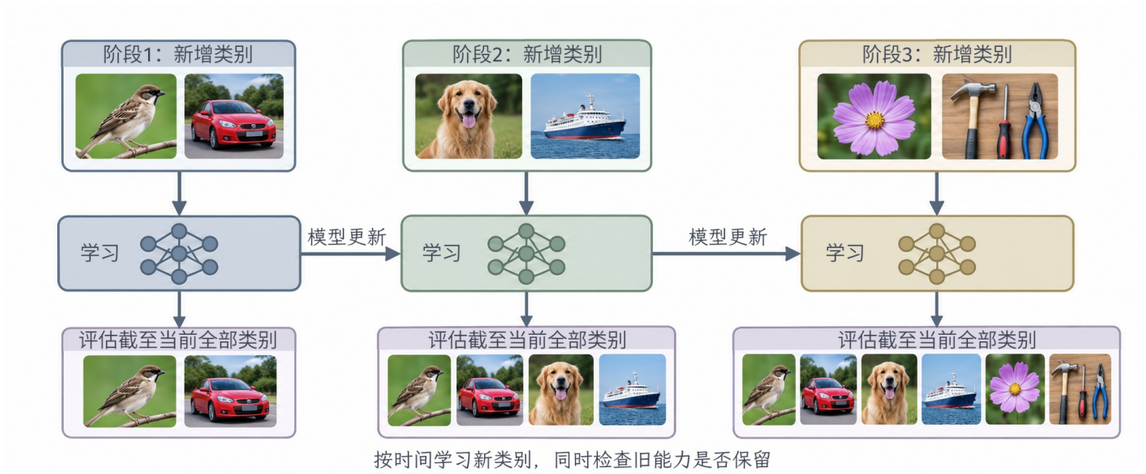

沿用原对比编号；图片等比例适配对比框，实际书页尺寸以卷三 PDF 为准。

019　范式简介

fig:multi-task-learning-process | 恢复旧设计，保留色阶并修正文字排版

提交前的原设计 · fbb26aec

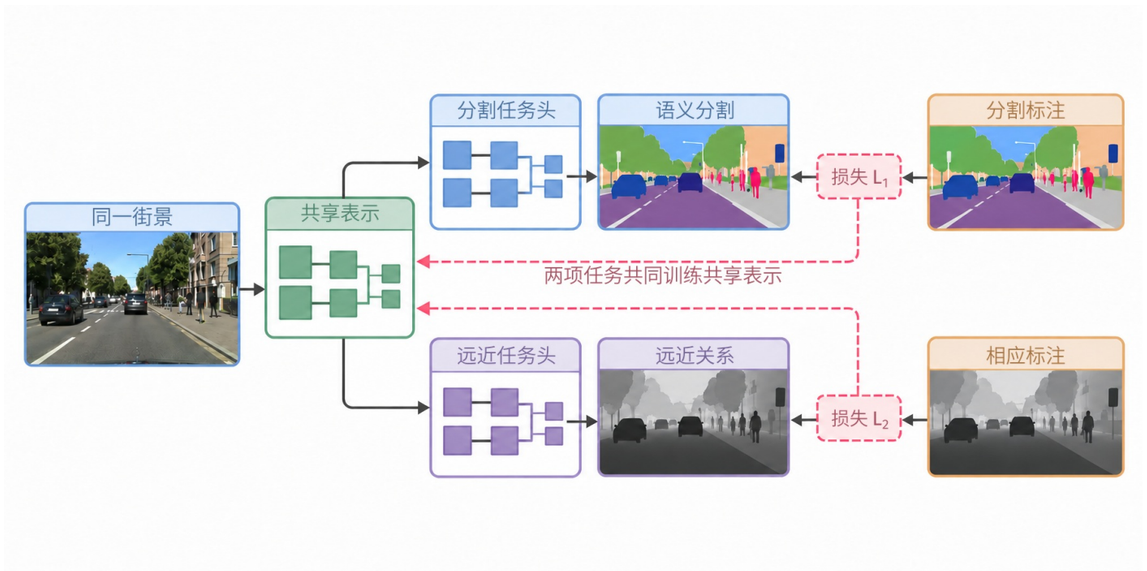

本次恢复版

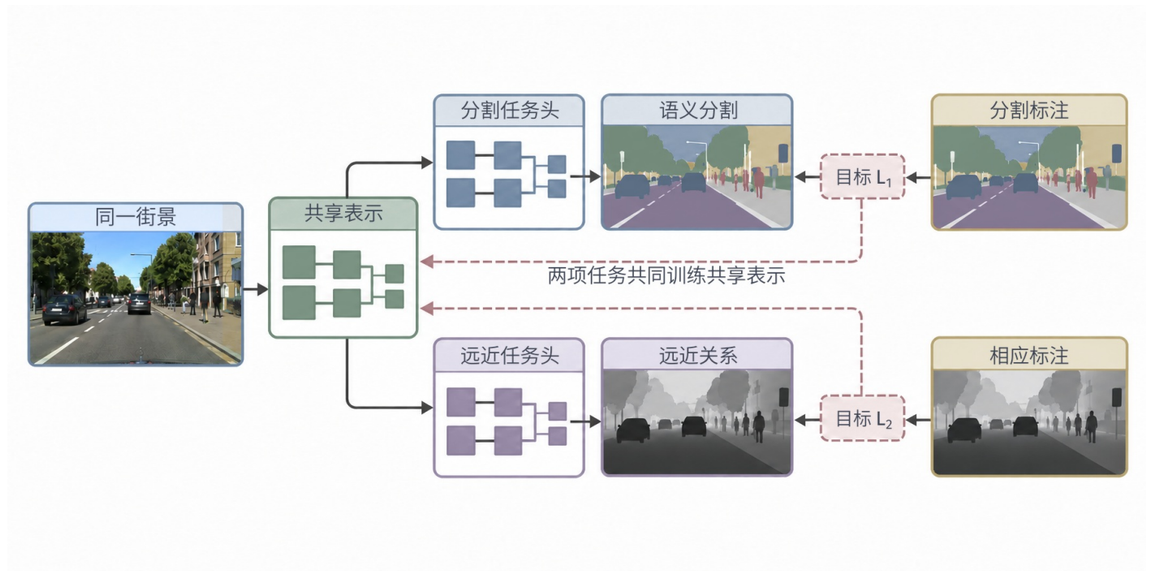

020　范式简介

fig:transfer-learning-process | 恢复旧设计，保留色阶并修正文字排版

提交前的原设计 · fbb26aec

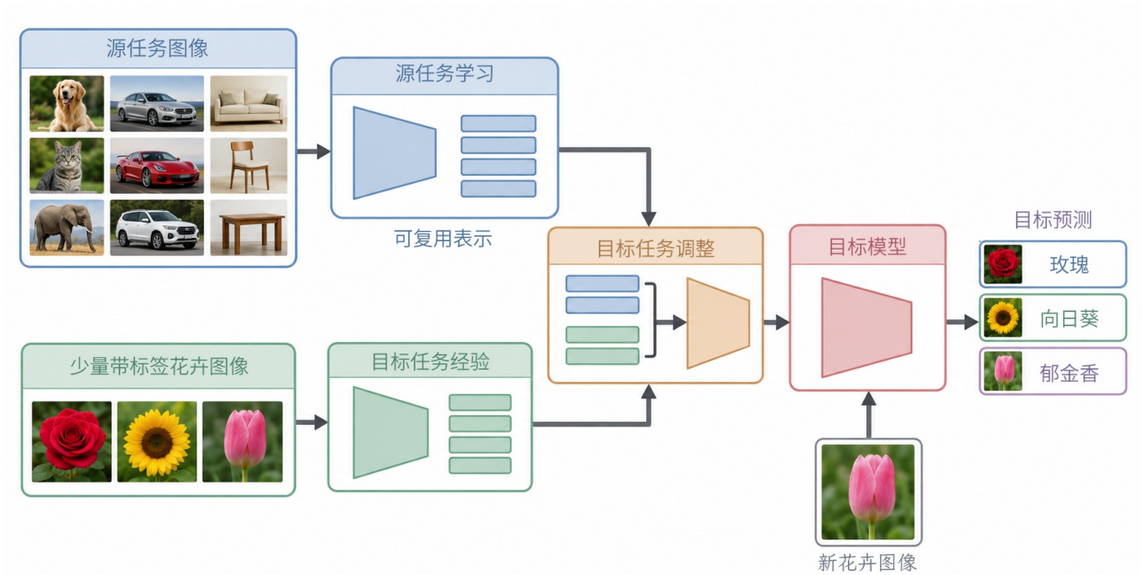

本次恢复版

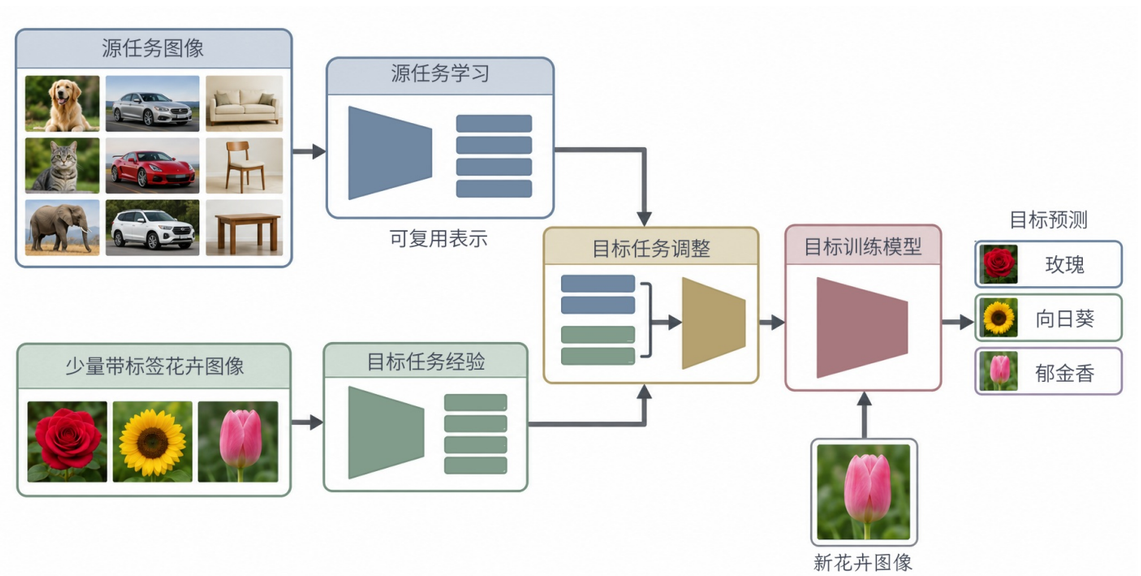

021　范式简介

fig:meta-learning-process | 恢复旧设计，保留色阶并修正文字排版

提交前的原设计 · fbb26aec

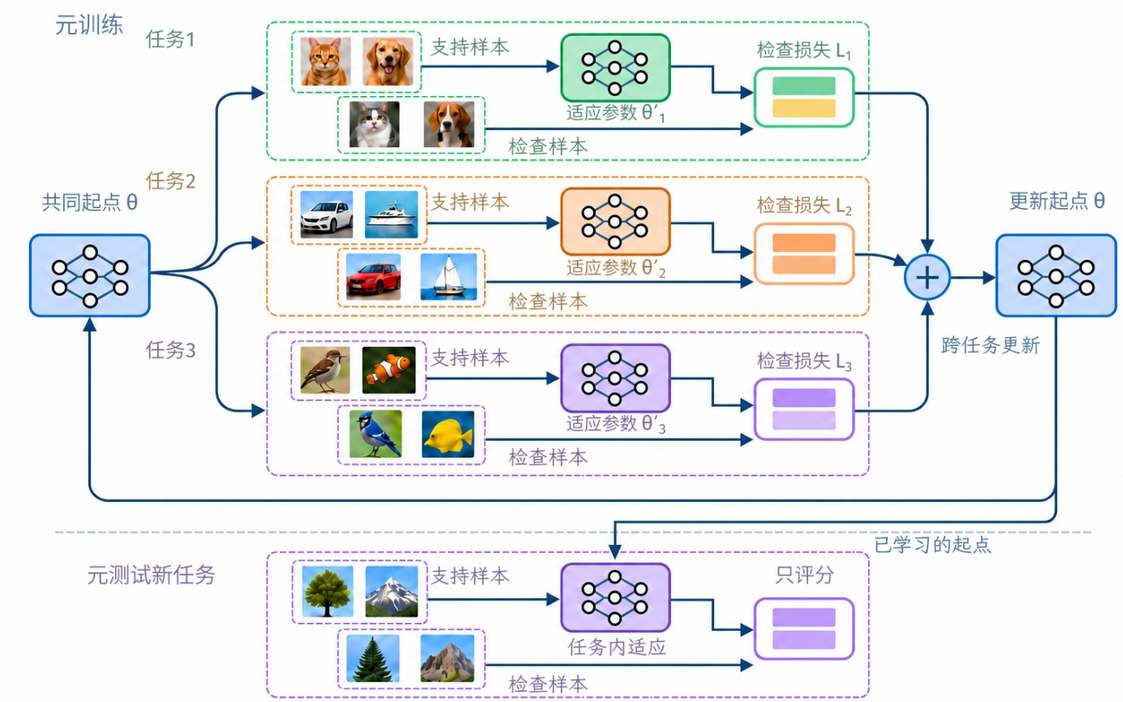

本次恢复版

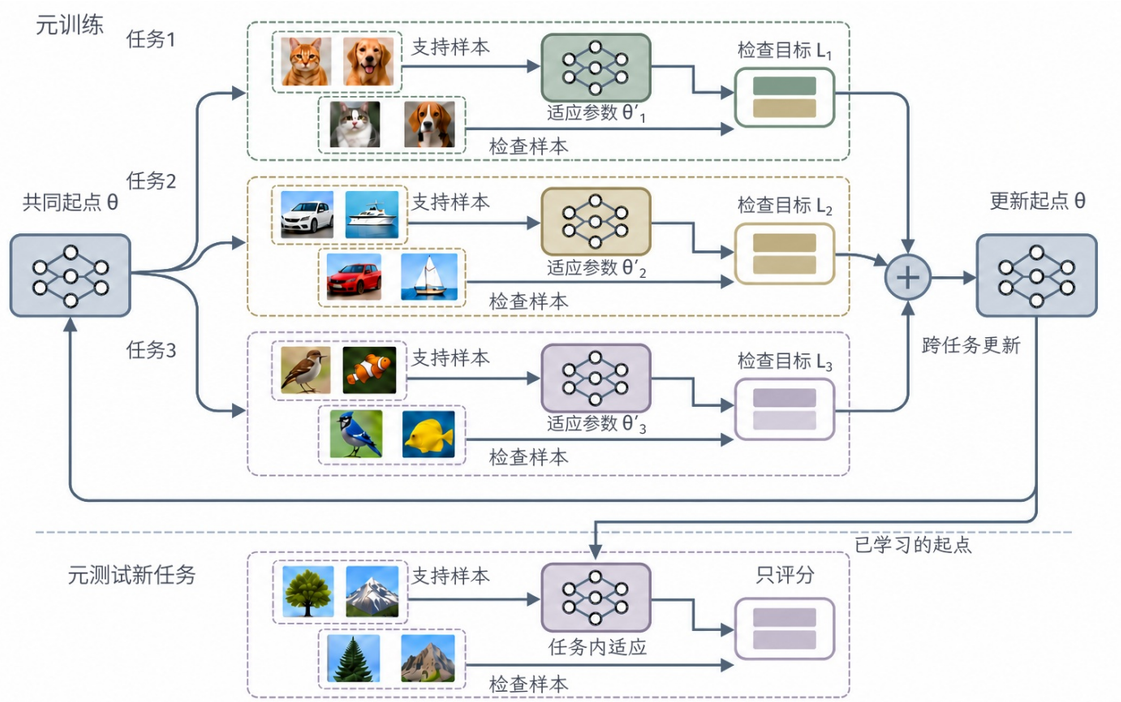

沿用原对比编号；图片等比例适配对比框，实际书页尺寸以卷三 PDF 为准。

022　范式简介

fig:online-feedback-order | 恢复旧设计，保留色阶并修正文字排版

提交前的原设计 · fbb26aec

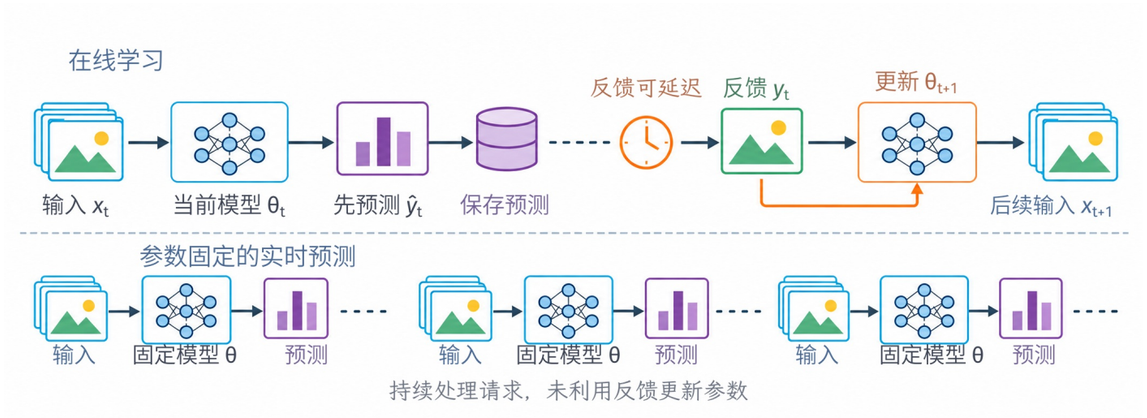

本次恢复版

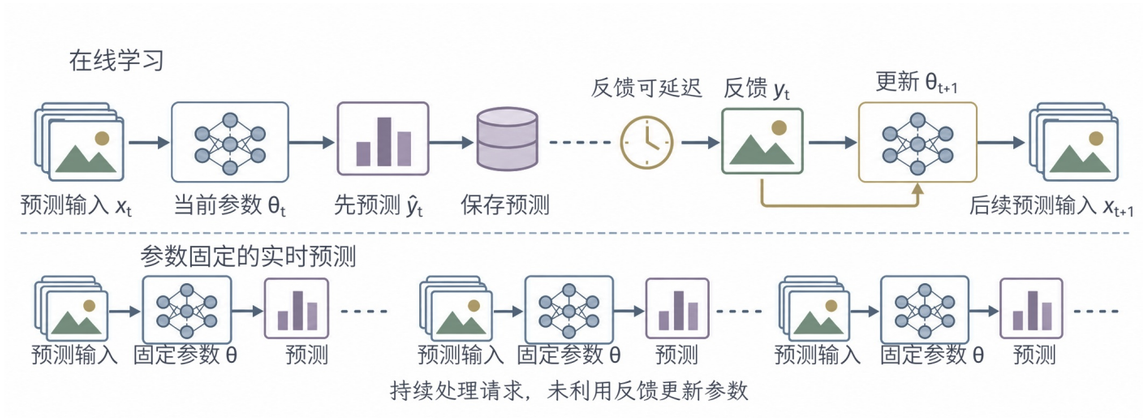

023　范式简介

fig:federated-learning-process | 恢复旧设计，保留色阶并修正文字排版

提交前的原设计 · fbb26aec

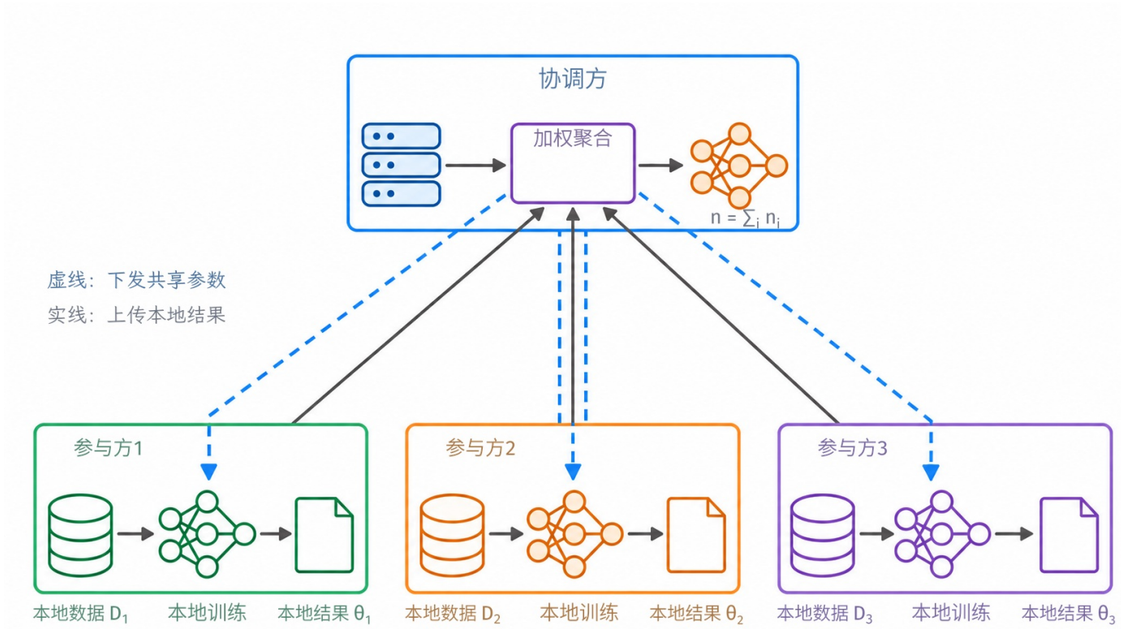

本次恢复版

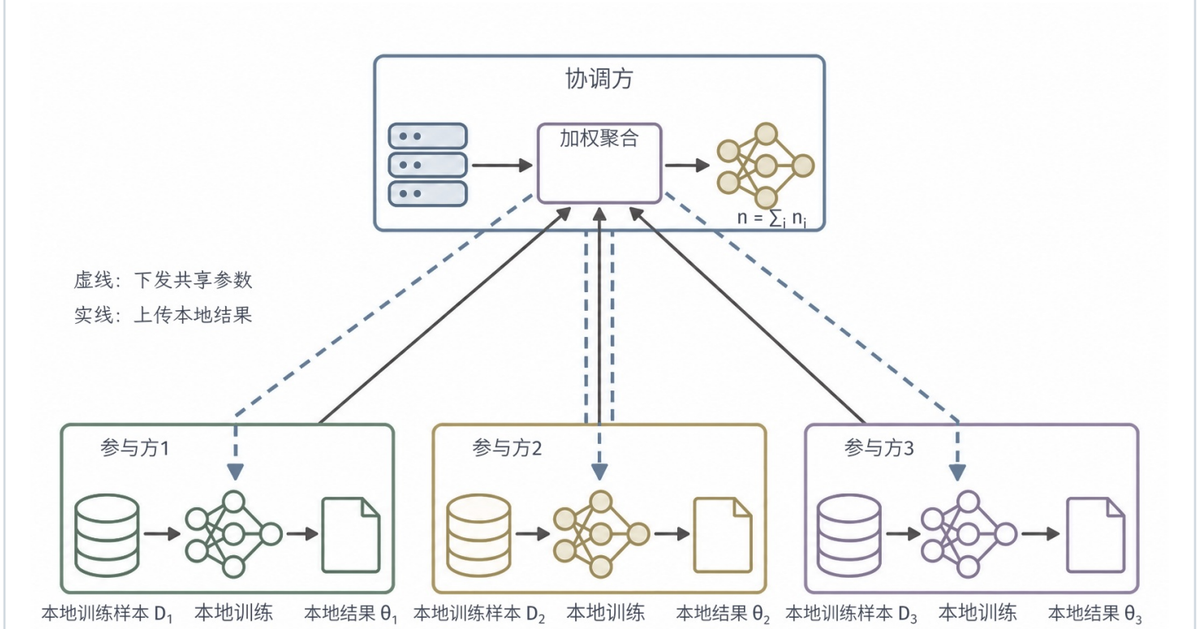

024　范式简介

fig:paradigm-combination-alphago | 恢复旧设计，保留色阶并修正文字排版

提交前的原设计 · fbb26aec

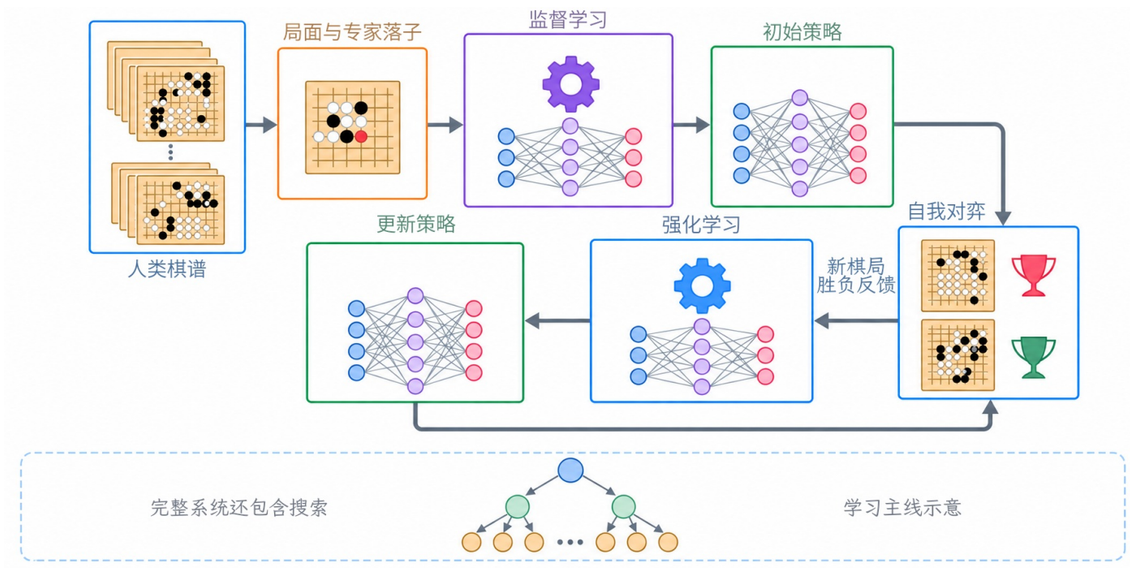

本次恢复版

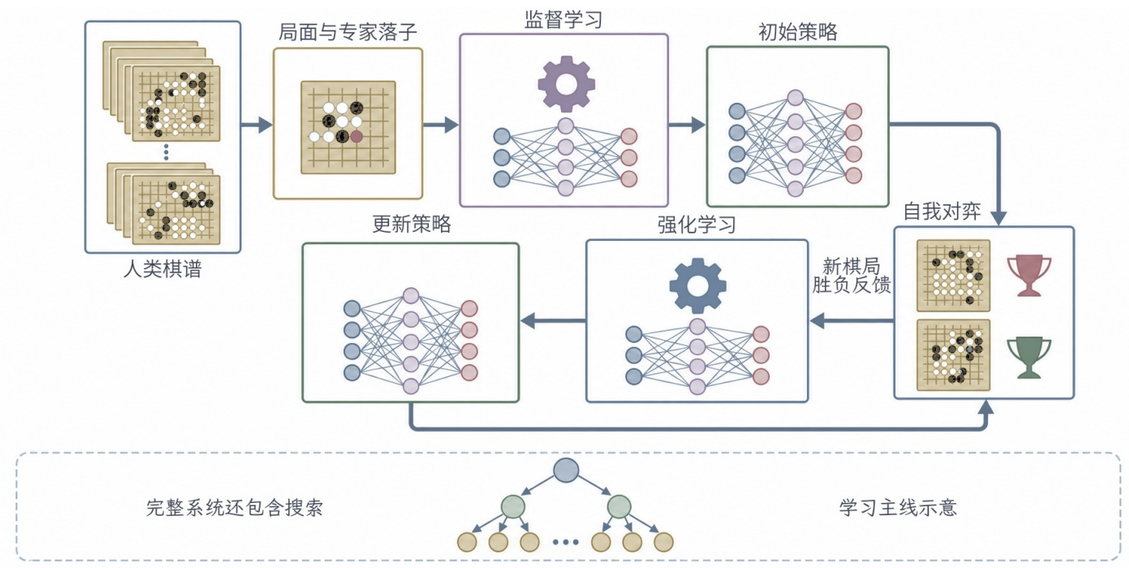

沿用原对比编号；图片等比例适配对比框，实际书页尺寸以卷三 PDF 为准。

025 机器学习理论基础

fig:learning-two-randomness | 恢复旧设计，保留色阶并修正文字排版

提交前的原设计 · fbb26aec

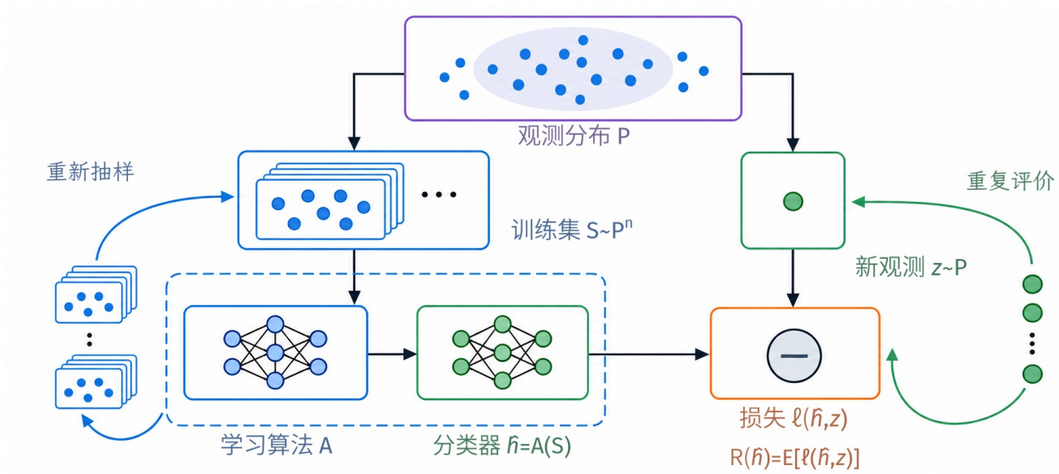

本次恢复版

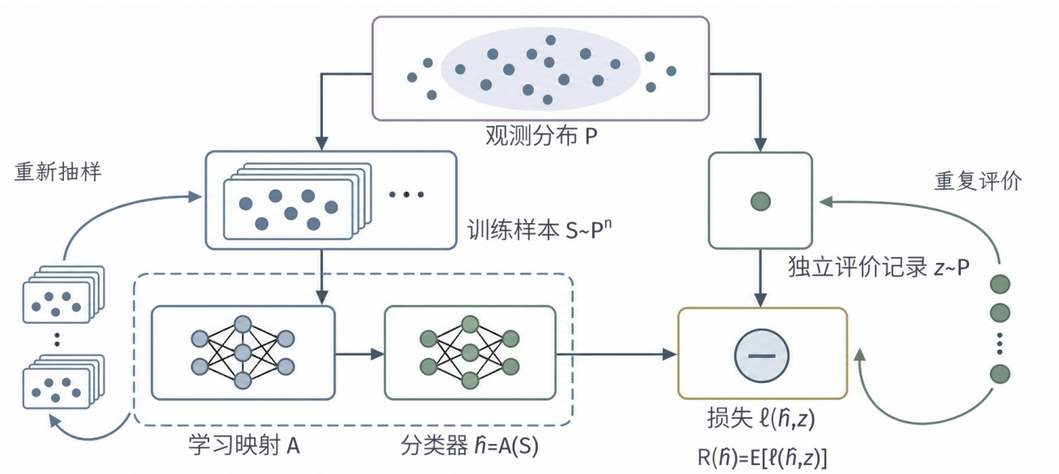

026 机器学习理论基础

fig:learning-no-free-lunch | 恢复旧设计，保留色阶并修正文字排版

提交前的原设计 · fbb26aec

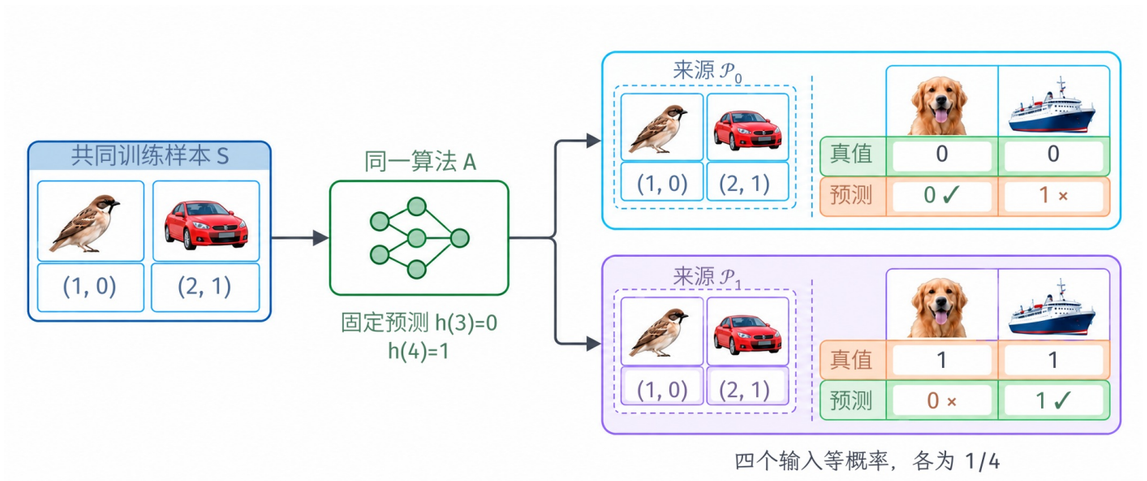

本次恢复版

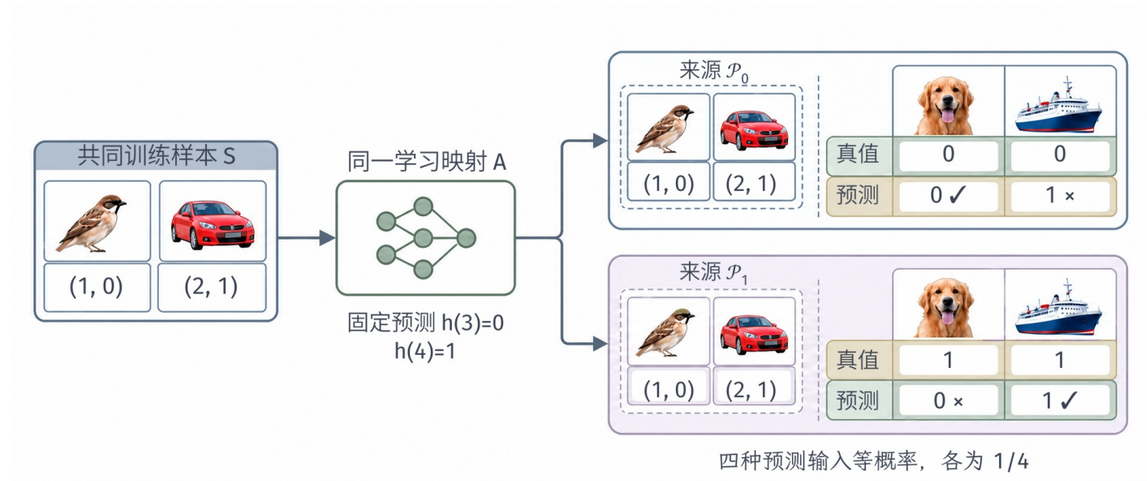

沿用原对比编号；图片等比例适配对比框，实际书页尺寸以卷三 PDF 为准。

032　一般学习的可学习性

fig:learning-stability | 恢复旧设计，保留色阶并修正文字排版

提交前的原设计 · fbb26aec

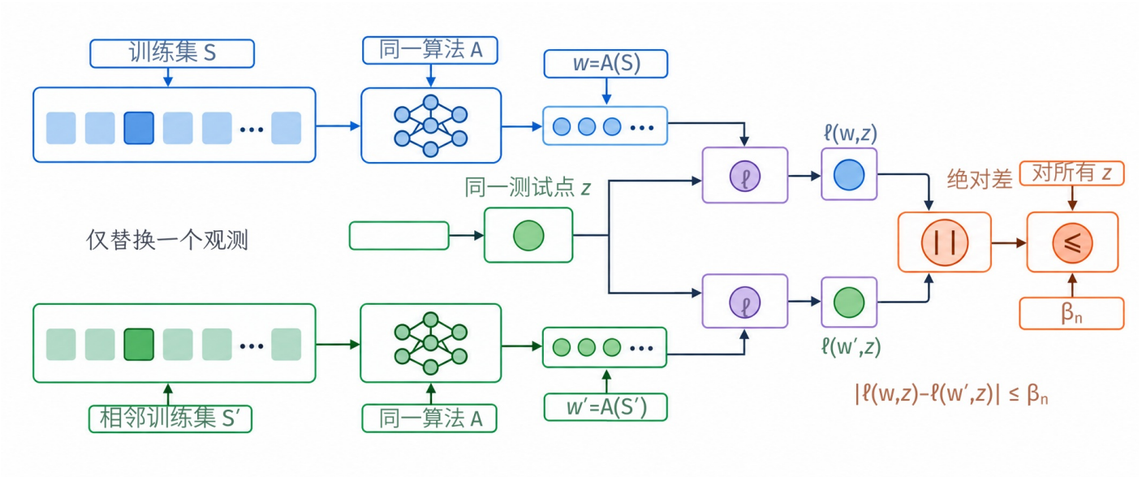

本次恢复版

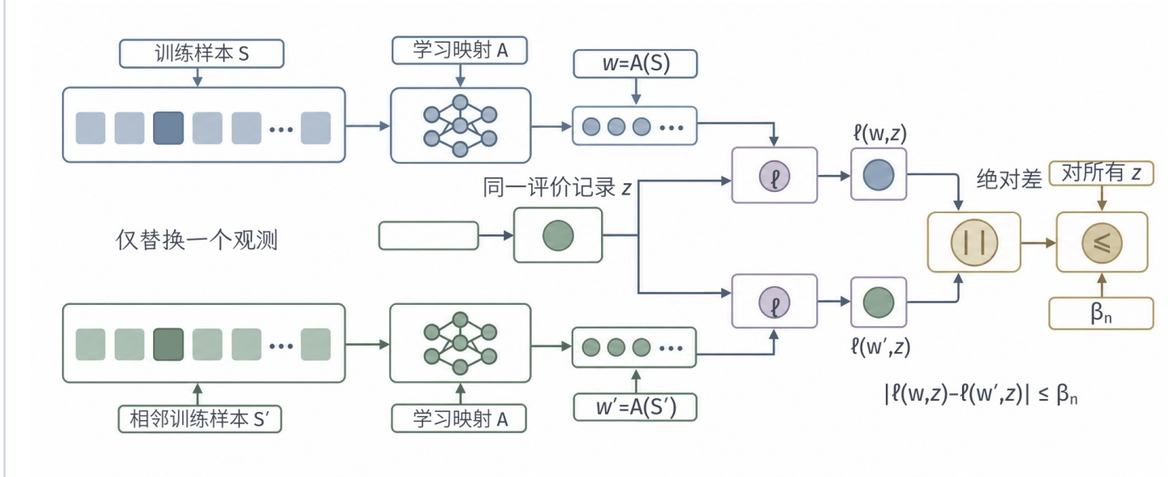

033 一般学习的可学习性

fig:conditional-information | 恢复旧设计，保留色阶并修正文字排版

提交前的原设计 · fbb26aec

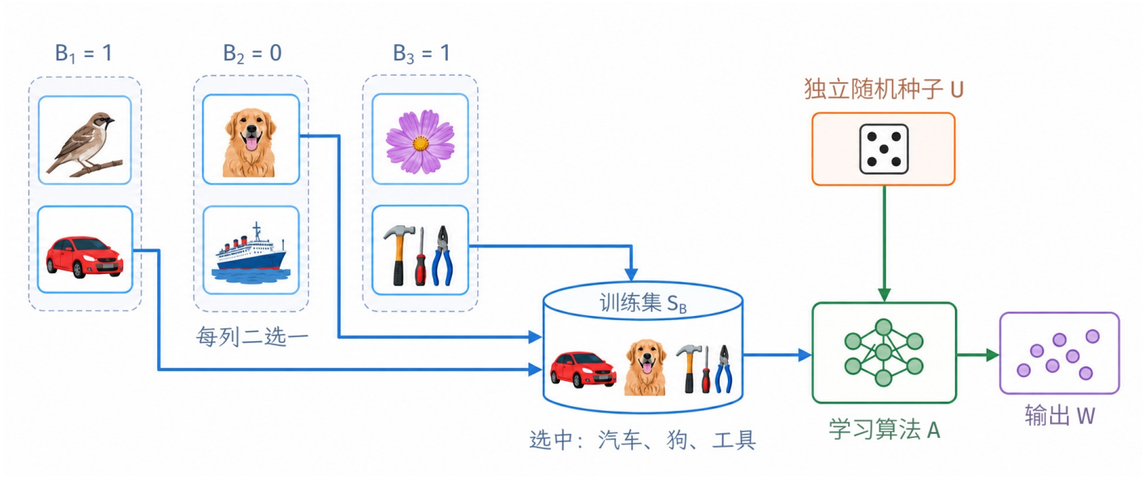

本次恢复版

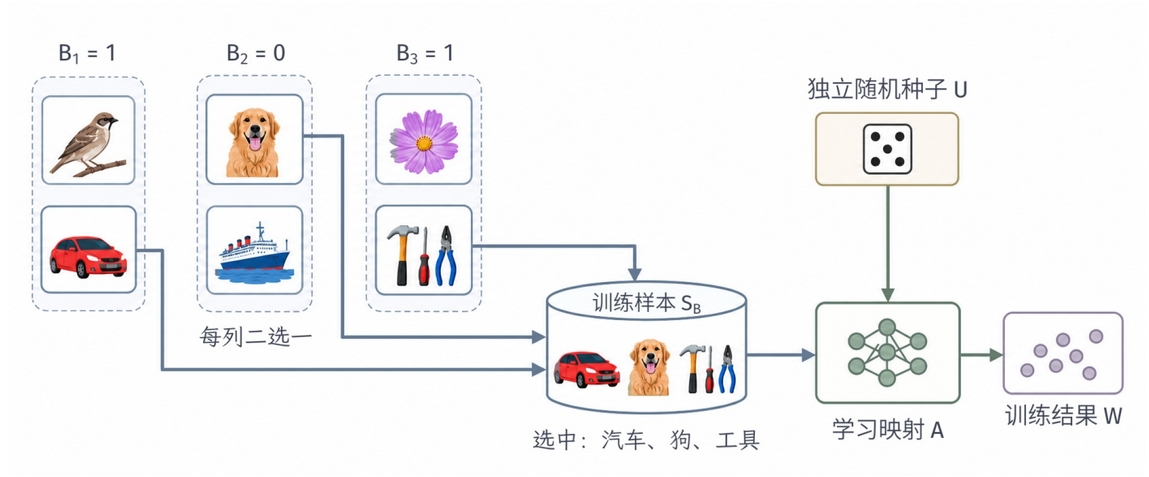

034　一般学习的可学习性

fig:learning-risk-routes | 恢复旧设计，保留色阶并修正文字排版

提交前的原设计 · fbb26aec

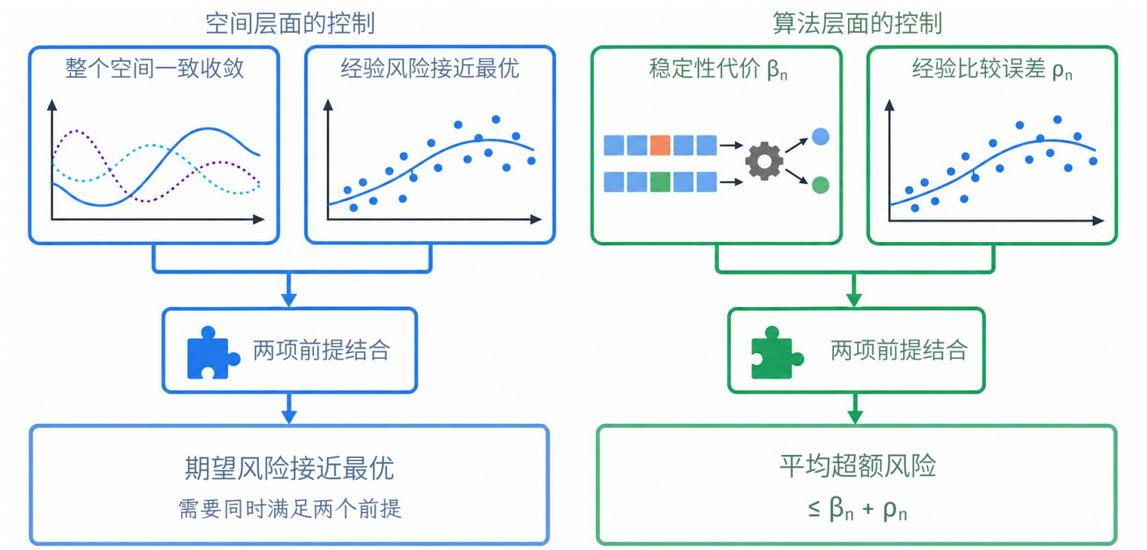

本次恢复版

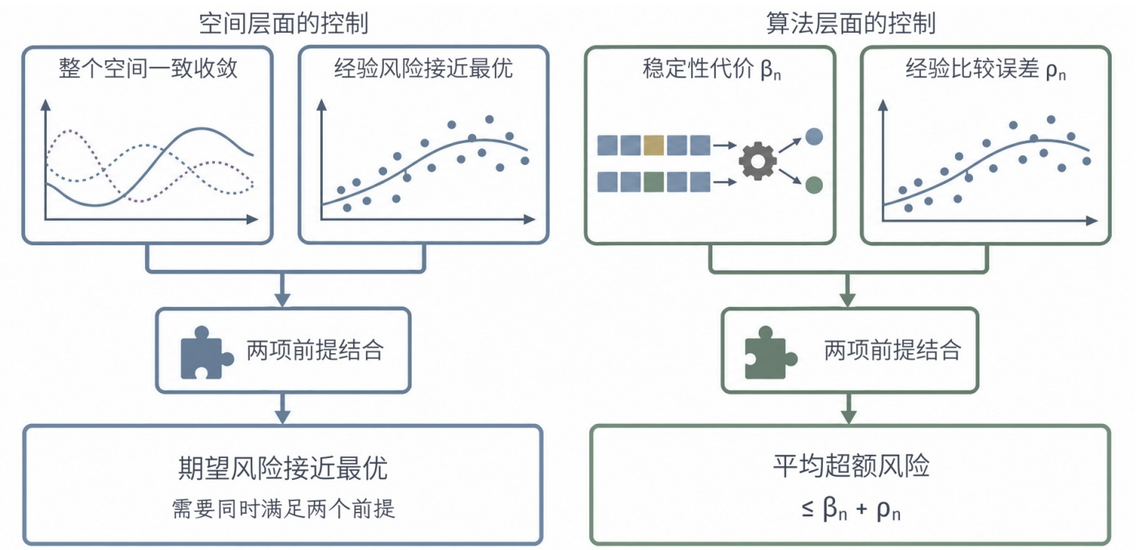

036 深度学习的可学习性

fig:learning-deep-selection | 恢复旧设计，保留色阶并修正文字排版

提交前的原设计 · fbb26aec

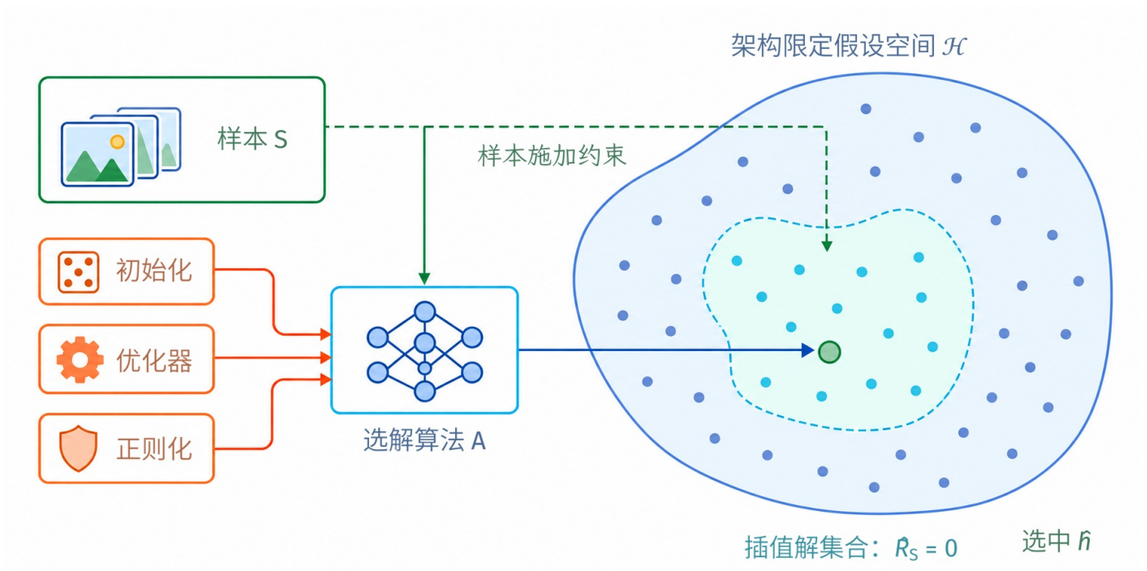

本次恢复版

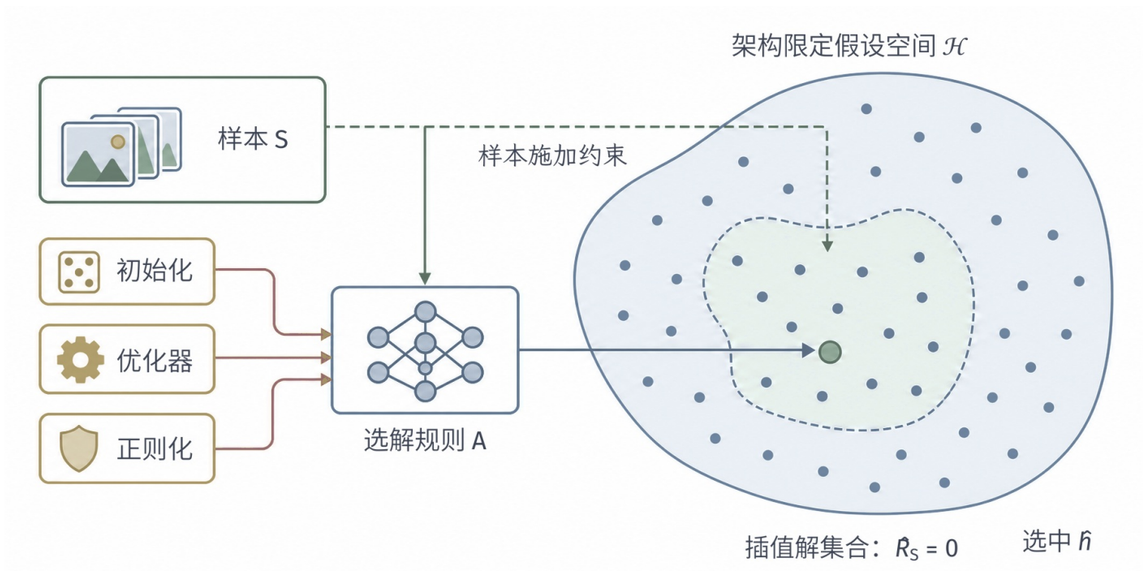

040 深度学习的可学习性

fig:learning-ntk-features | 恢复旧设计，保留色阶并修正文字排版

提交前的原设计 · fbb26aec

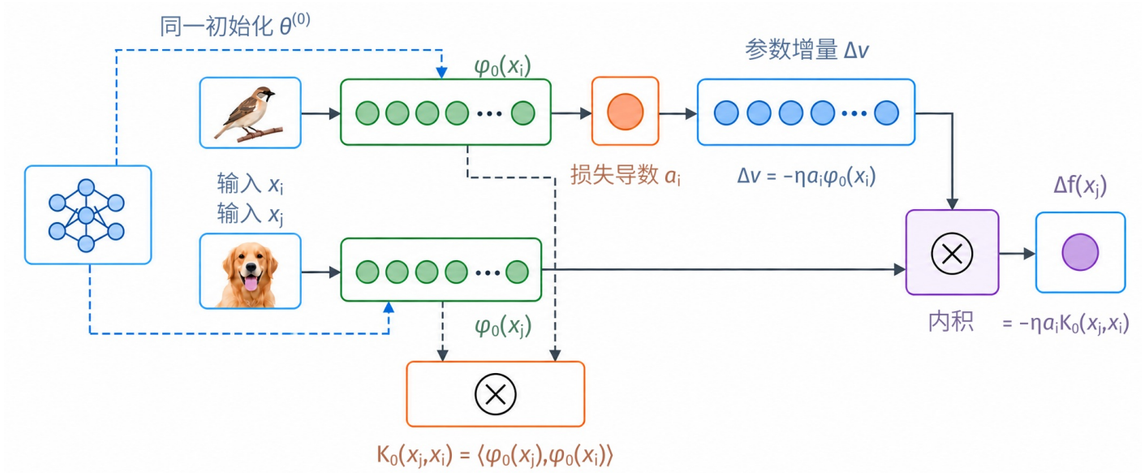

本次恢复版

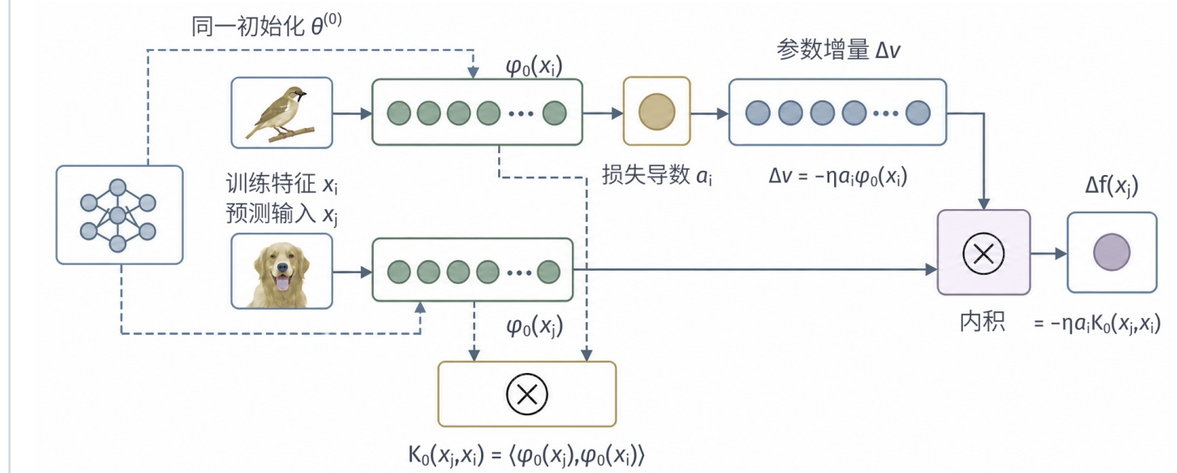

沿用原对比编号；图片等比例适配对比框，实际书页尺寸以卷三 PDF 为准。

042 深度学习的可学习性

fig:parameter-distribution-semantics | 恢复旧设计，保留色阶并修正文字排版

提交前的原设计 · fbb26aec

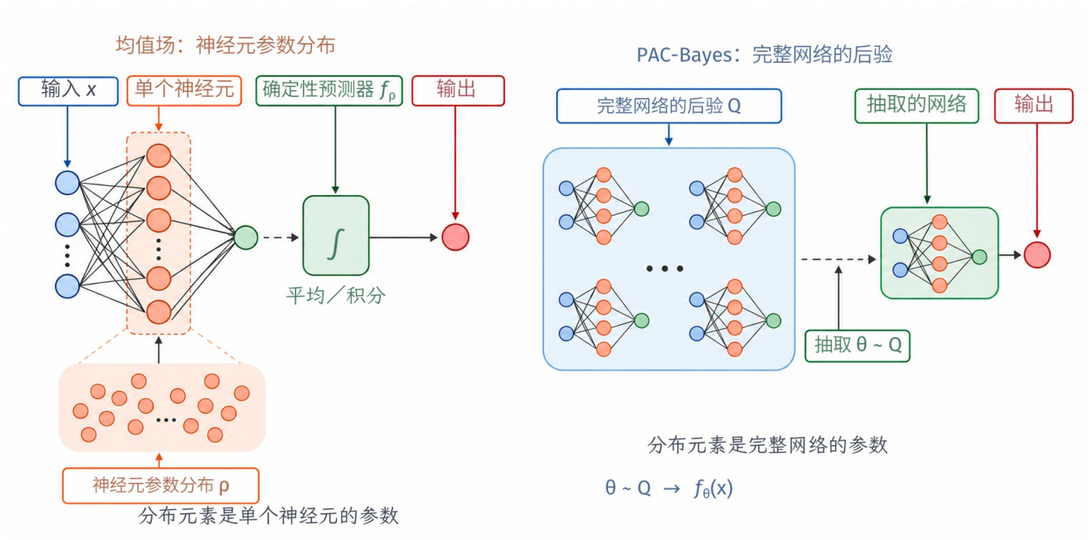

本次恢复版

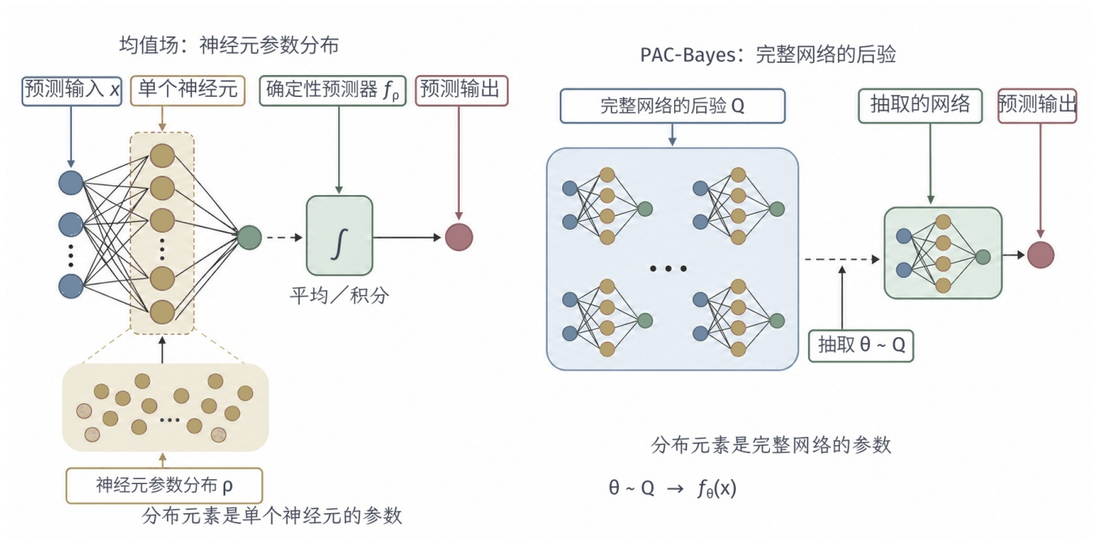

043 深度学习的可学习性

fig:learning-flat-sharp | 恢复旧设计，保留色阶并修正文字排版

提交前的原设计 · fbb26aec

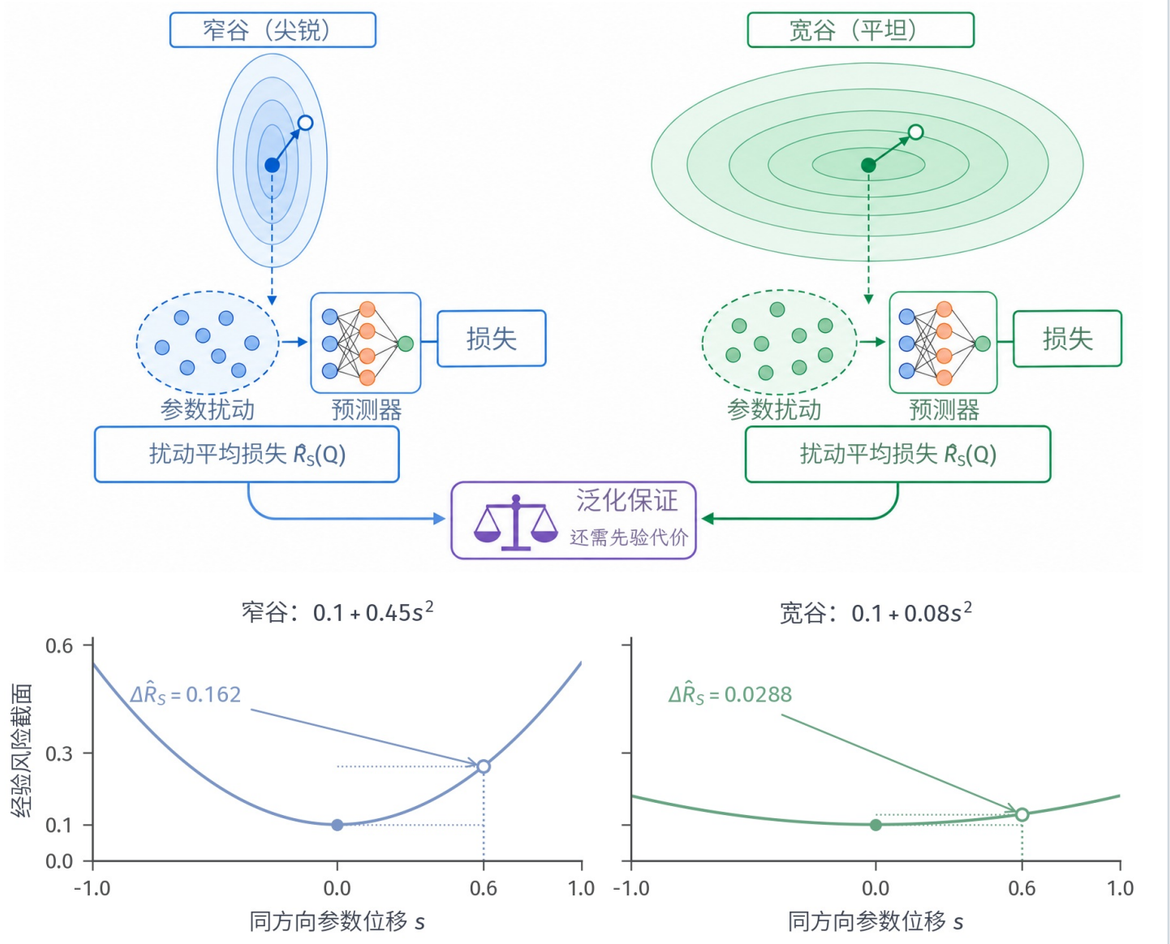

本次恢复版

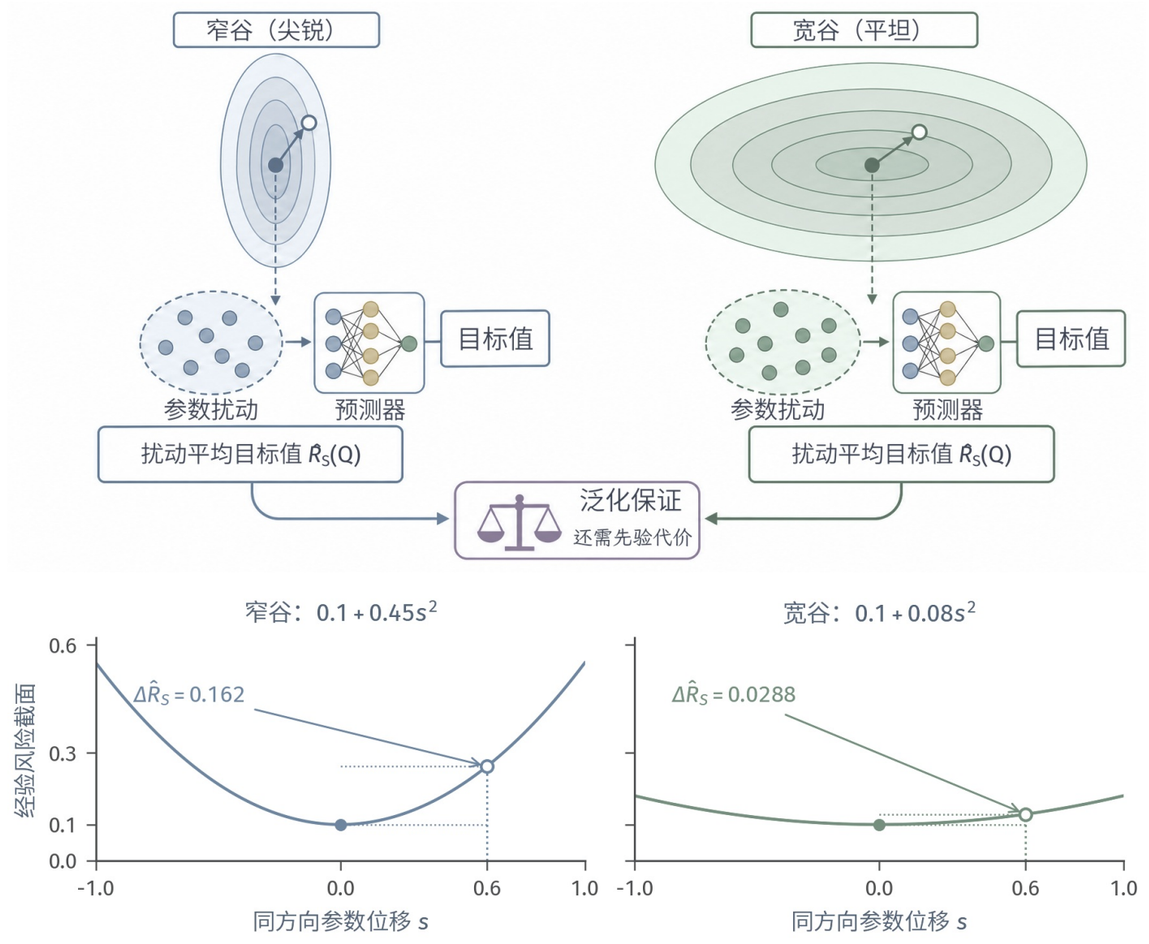

沿用原对比编号；图片等比例适配对比框，实际书页尺寸以卷三 PDF 为准。

046 迁移学习的可学习性

fig:learning-alignment-counterexample | 恢复旧设计，保留色阶并修正文字排版

提交前的原设计 · fbb26aec

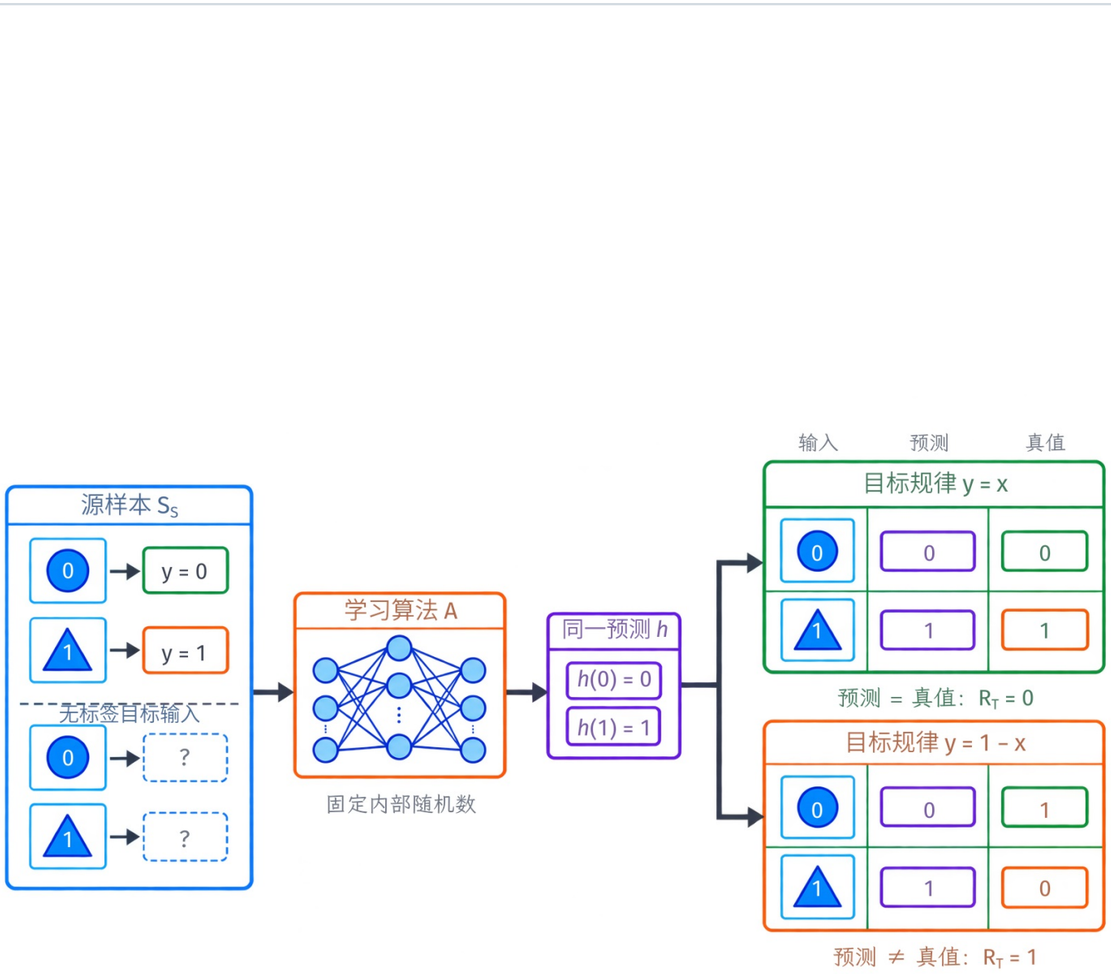

本次恢复版

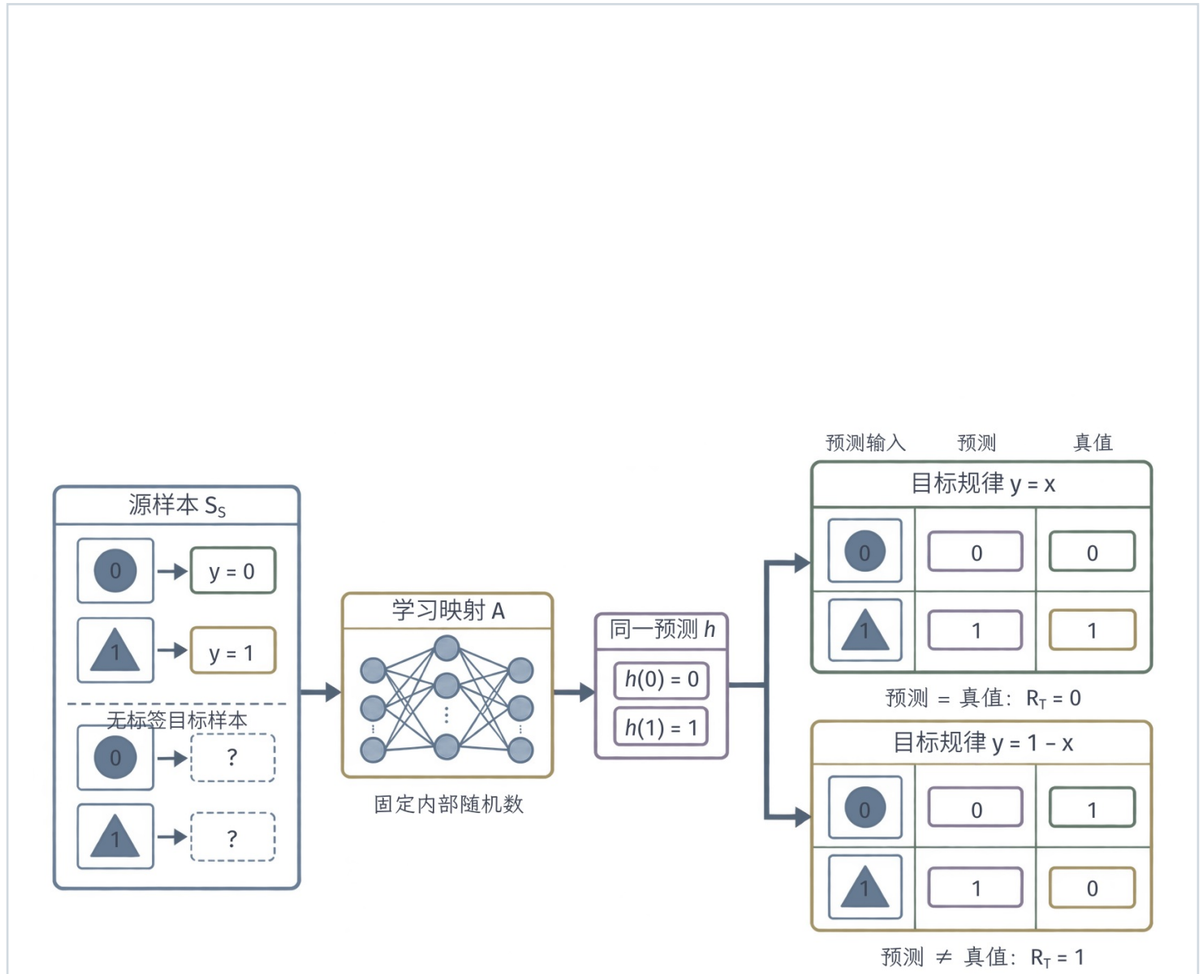

049 迁移学习的可学习性

fig:learning-environment-sampling | 恢复旧设计，保留色阶并修正文字排版

提交前的原设计 · fbb26aec

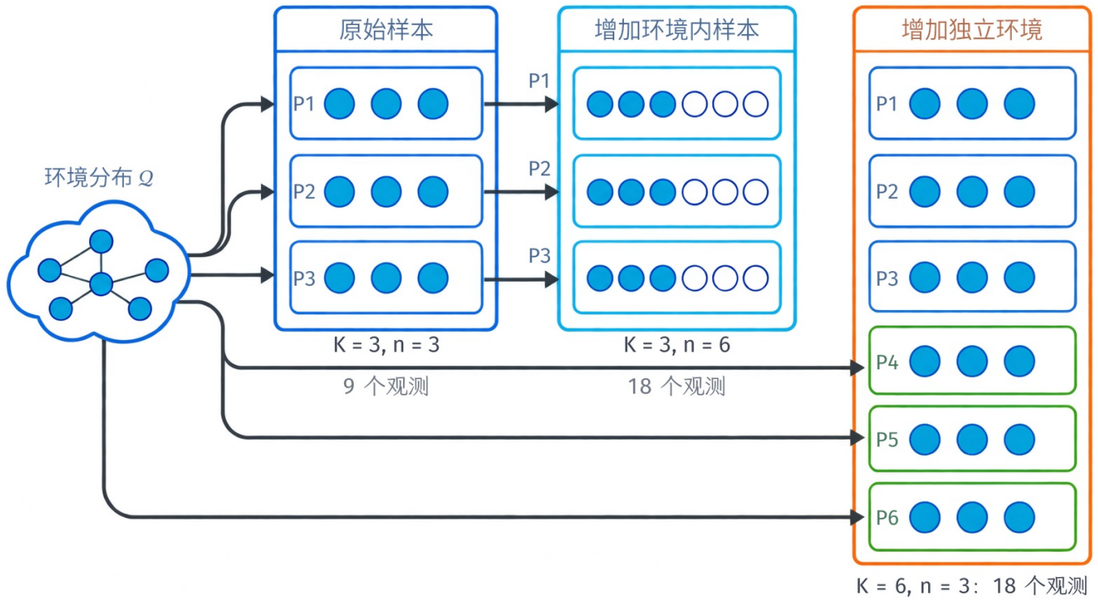

本次恢复版

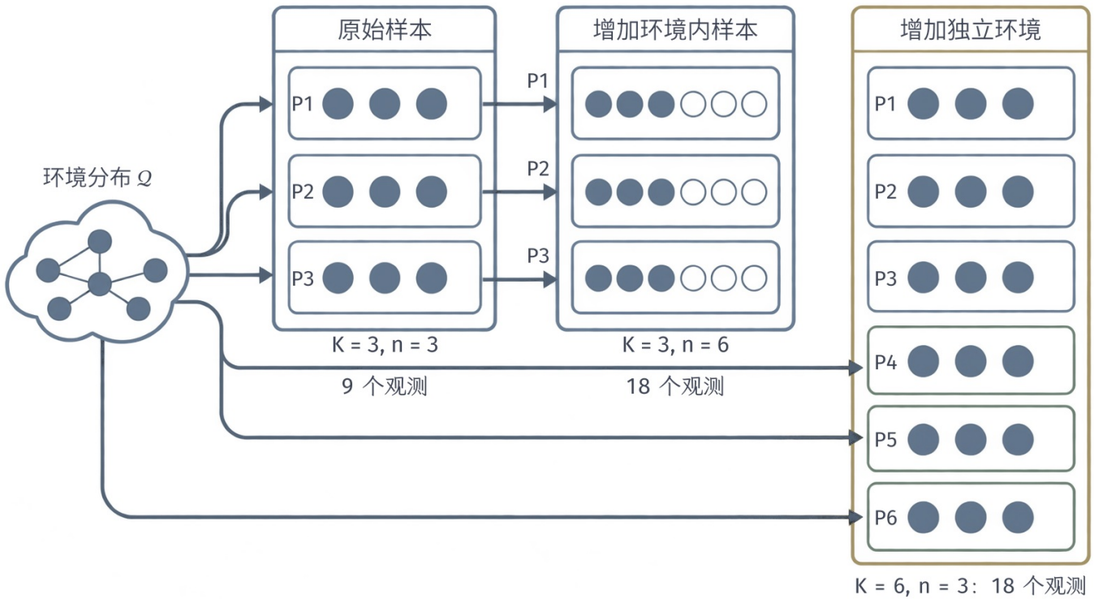

051　可信机器学习基础

fig:trust-three-layers | 恢复旧设计，保留色阶并修正文字排版

提交前的原设计 · fbb26aec

本次恢复版

沿用原对比编号；图片等比例适配对比框，实际书页尺寸以卷三 PDF 为准。

052　可信机器学习基础

fig:trust-decision-consequences | 恢复旧设计，保留色阶并修正文字排版

提交前的原设计 · fbb26aec

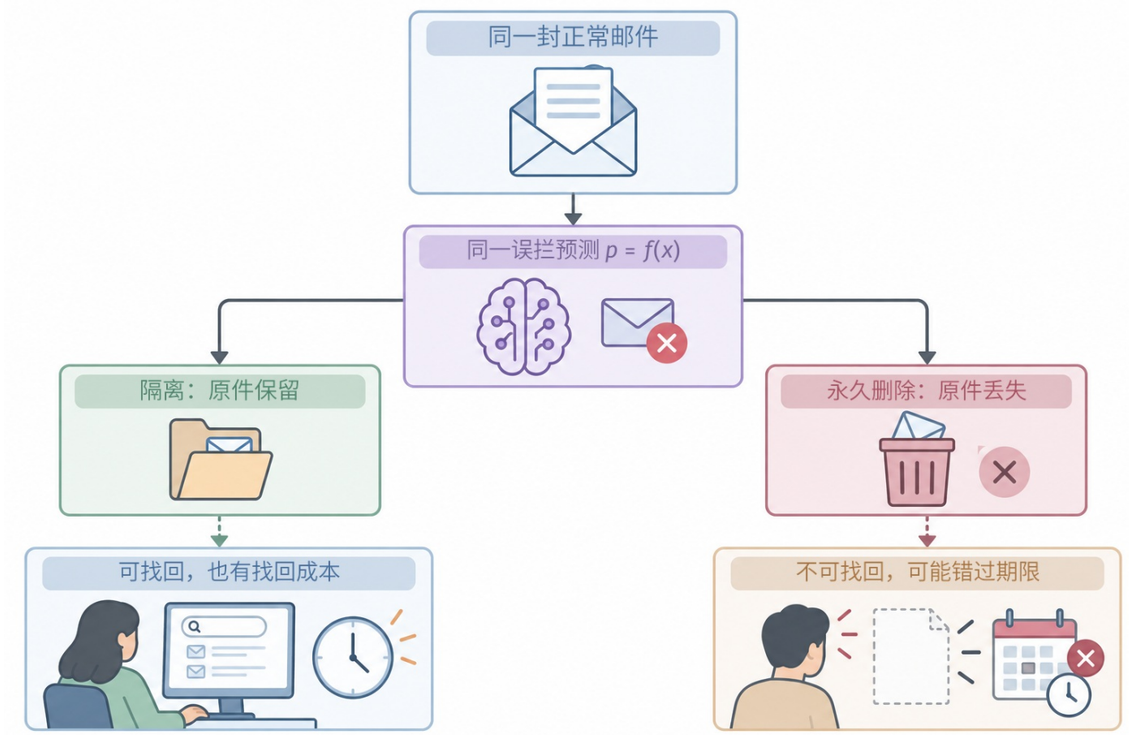

本次恢复版

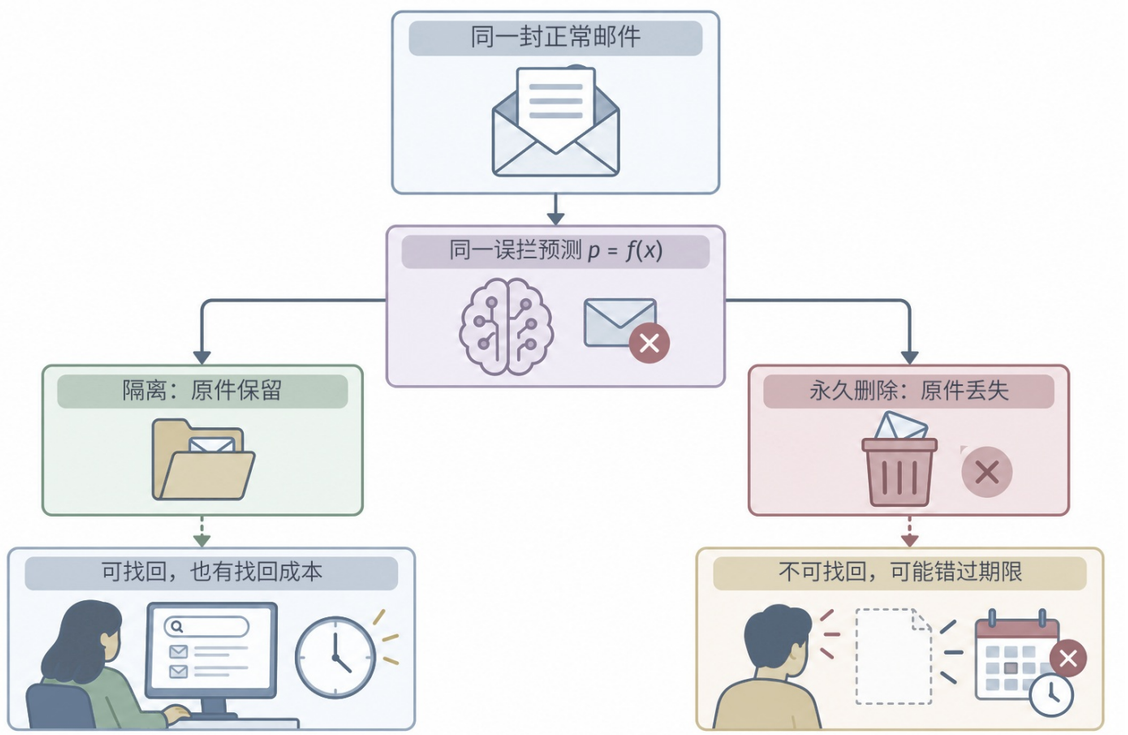

沿用原对比编号；图片等比例适配对比框，实际书页尺寸以卷三 PDF 为准。

054　可靠性

fig:trust-reliability-review | 恢复旧设计，保留色阶并修正文字排版

提交前的原设计 · fbb26aec

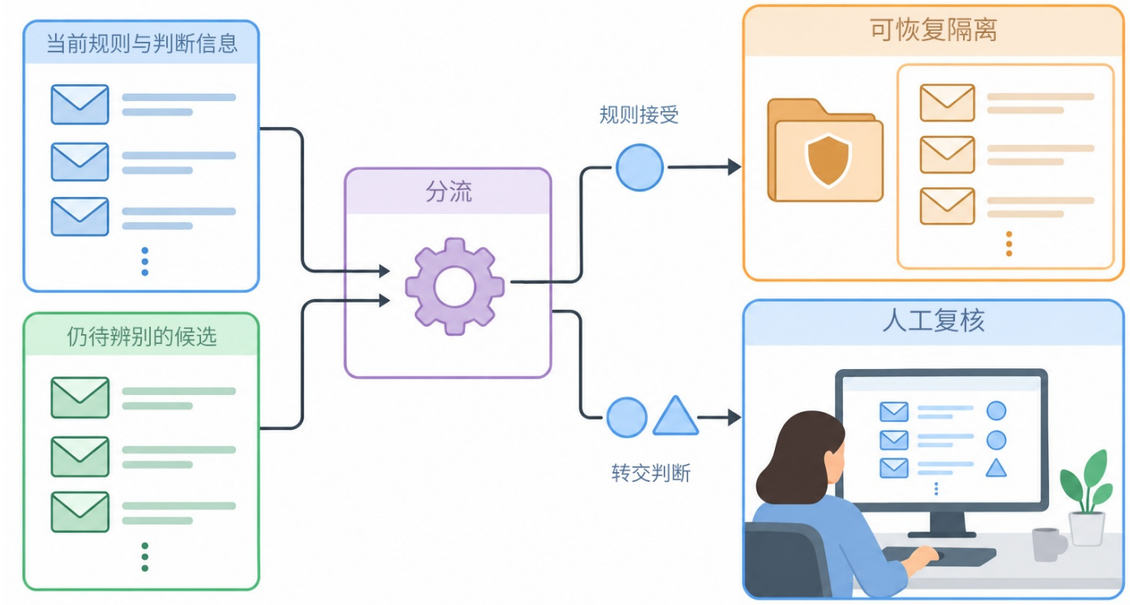

本次恢复版

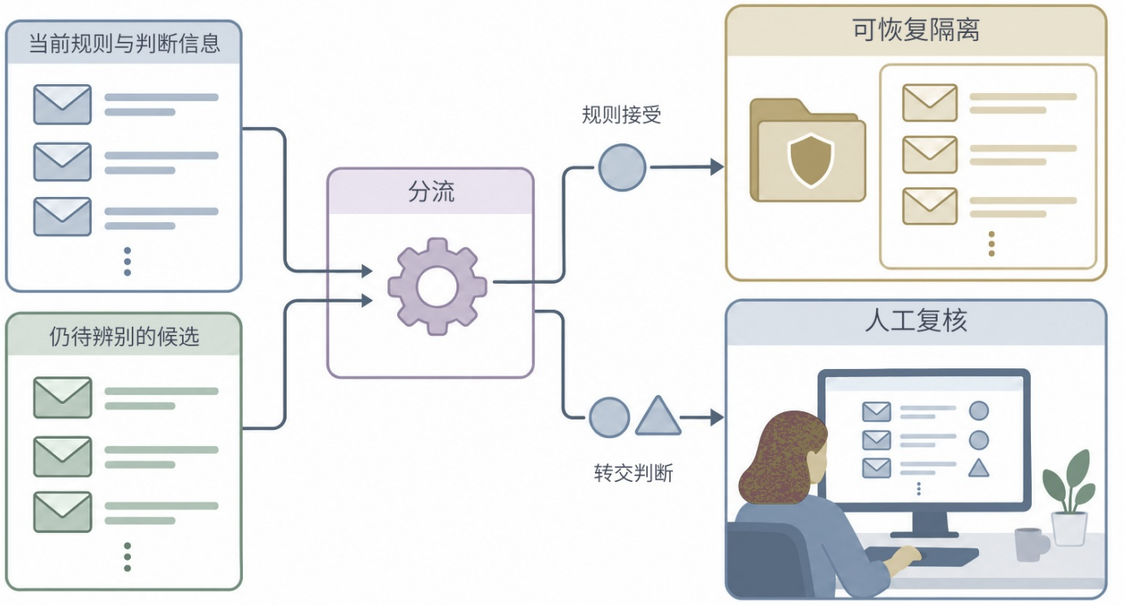

沿用原对比编号；图片等比例适配对比框，实际书页尺寸以卷三 PDF 为准。

055　可靠性

fig:trust-uncertainty-sources | 恢复旧设计，保留色阶并修正文字排版

提交前的原设计 · fbb26aec

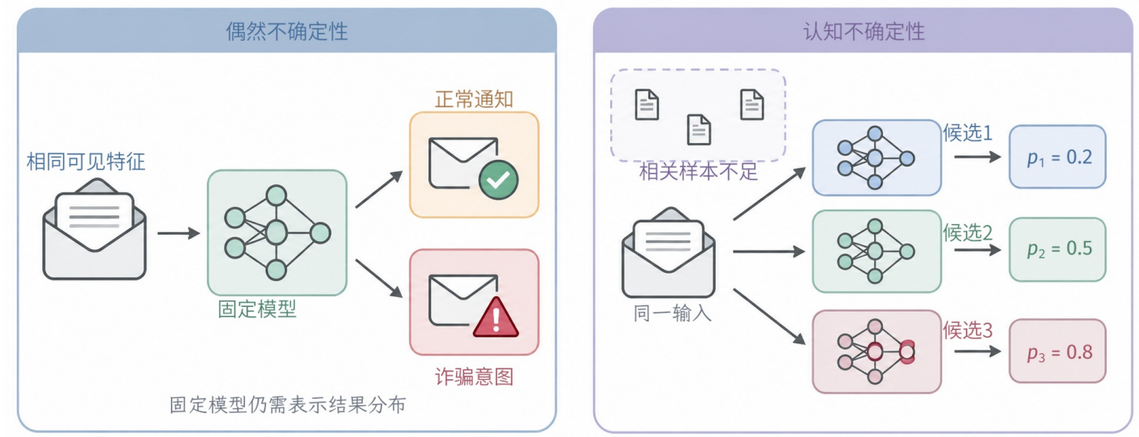

本次恢复版

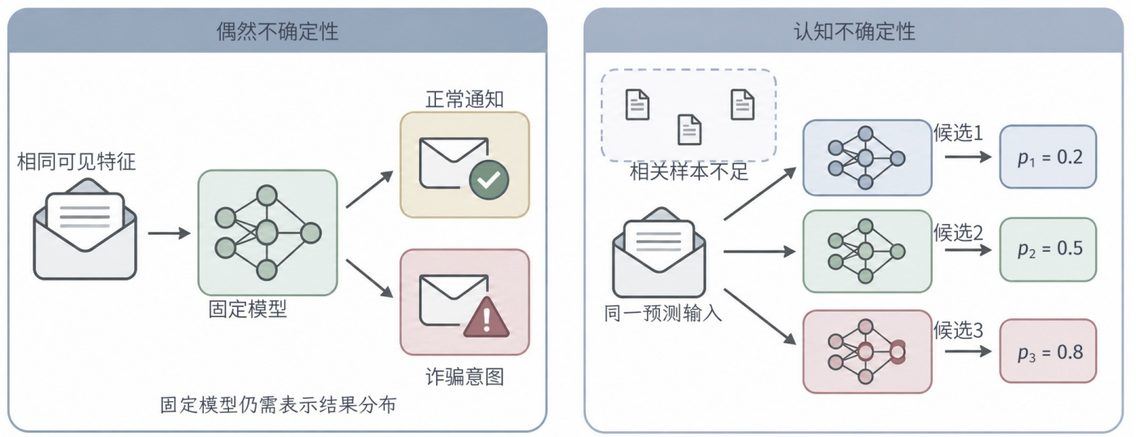

沿用原对比编号；图片等比例适配对比框，实际书页尺寸以卷三 PDF 为准。

056　可靠性

fig:trust-calibration-discrimination | 恢复旧设计，保留色阶并修正文字排版

提交前的原设计 · fbb26aec

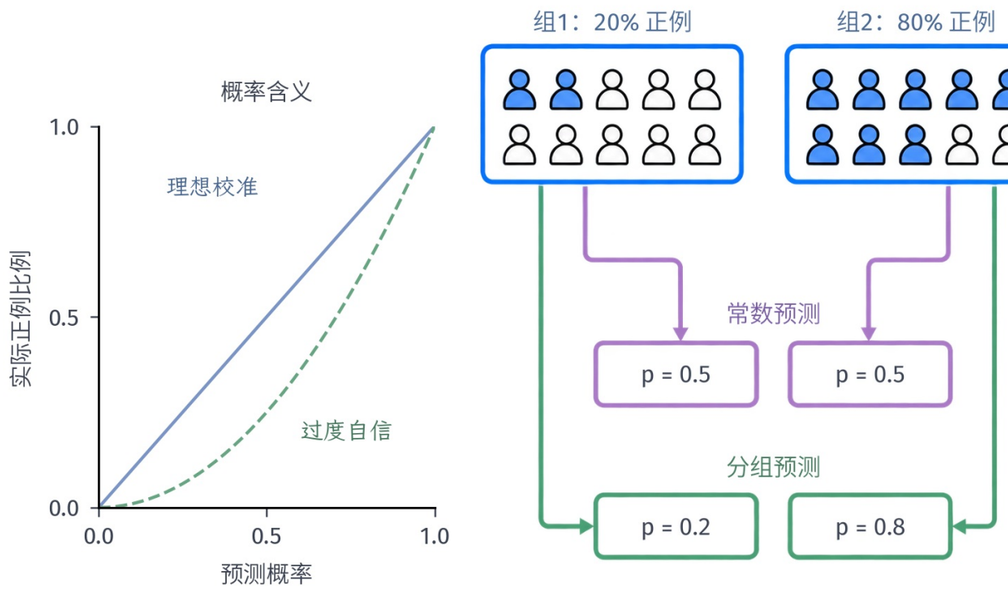

本次恢复版

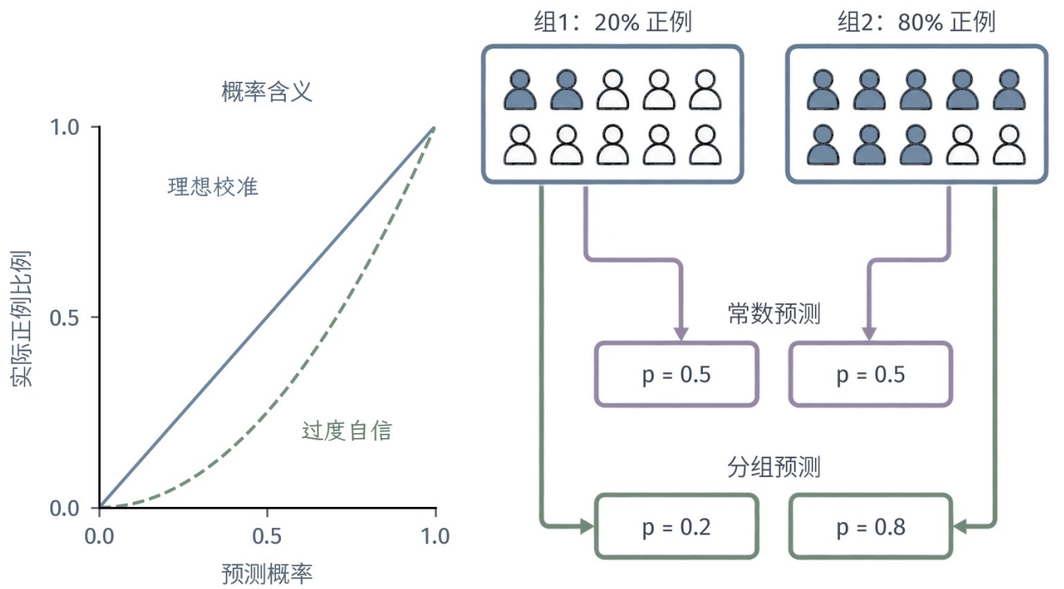

057　可靠性

fig:trust-selective-risk-coverage | 恢复旧设计，保留色阶并修正文字排版

提交前的原设计 · fbb26aec

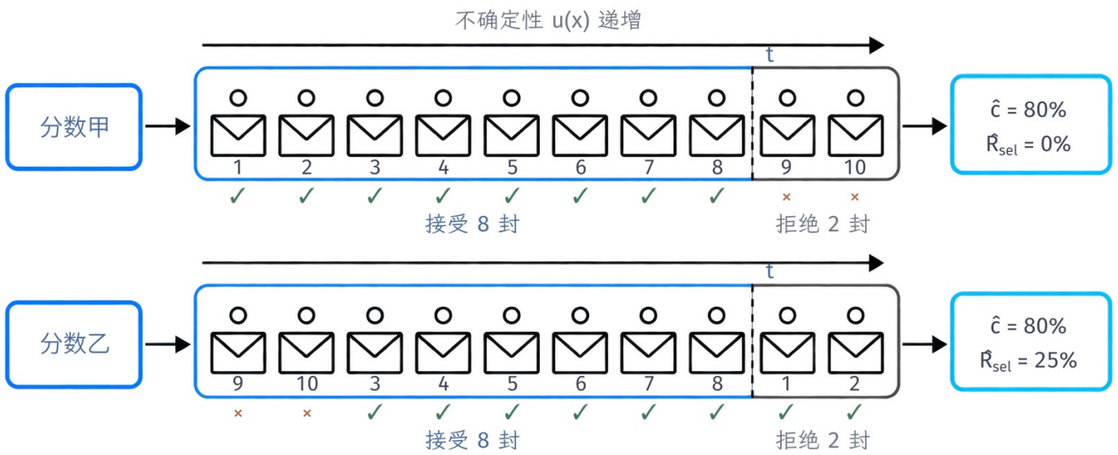

本次恢复版

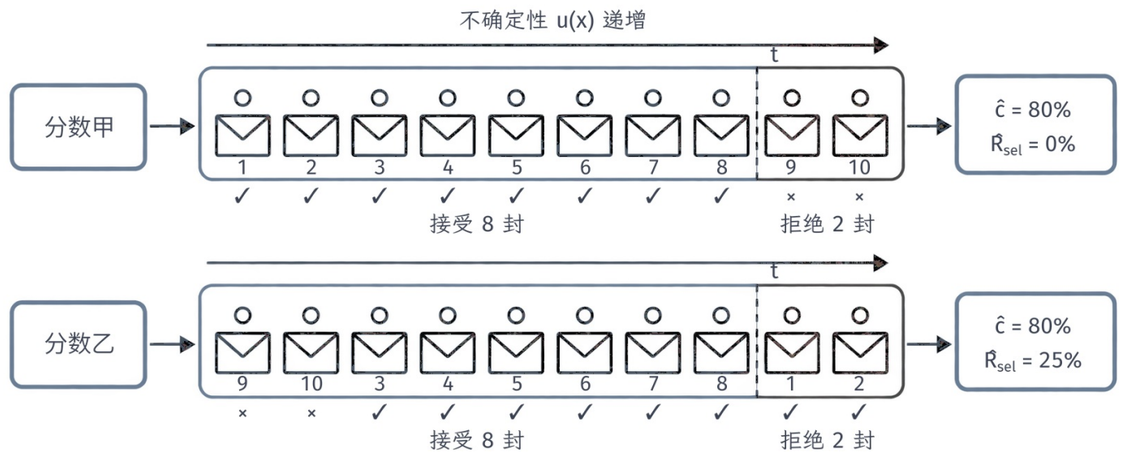

059　可靠性

fig:trust-conformal-construction | 恢复旧设计，保留色阶并修正文字排版

提交前的原设计 · fbb26aec

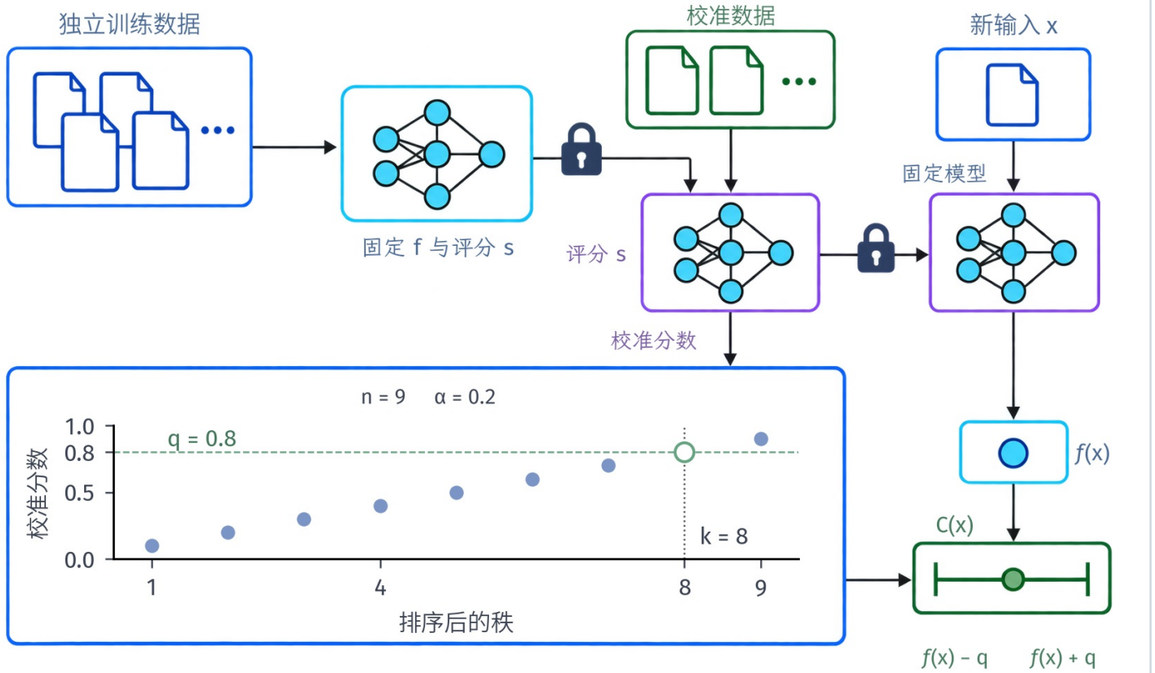

本次恢复版

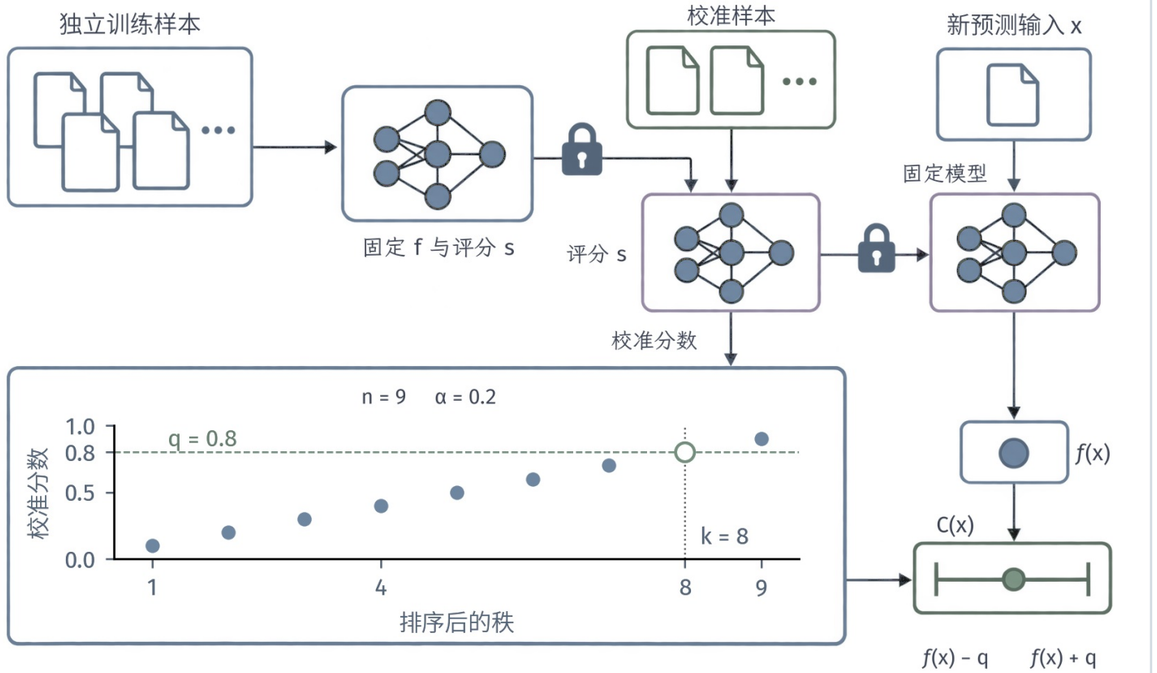

062　鲁棒性

fig:trust-adversarial-training-loops | 恢复旧设计，保留色阶并修正文字排版

提交前的原设计 · fbb26aec

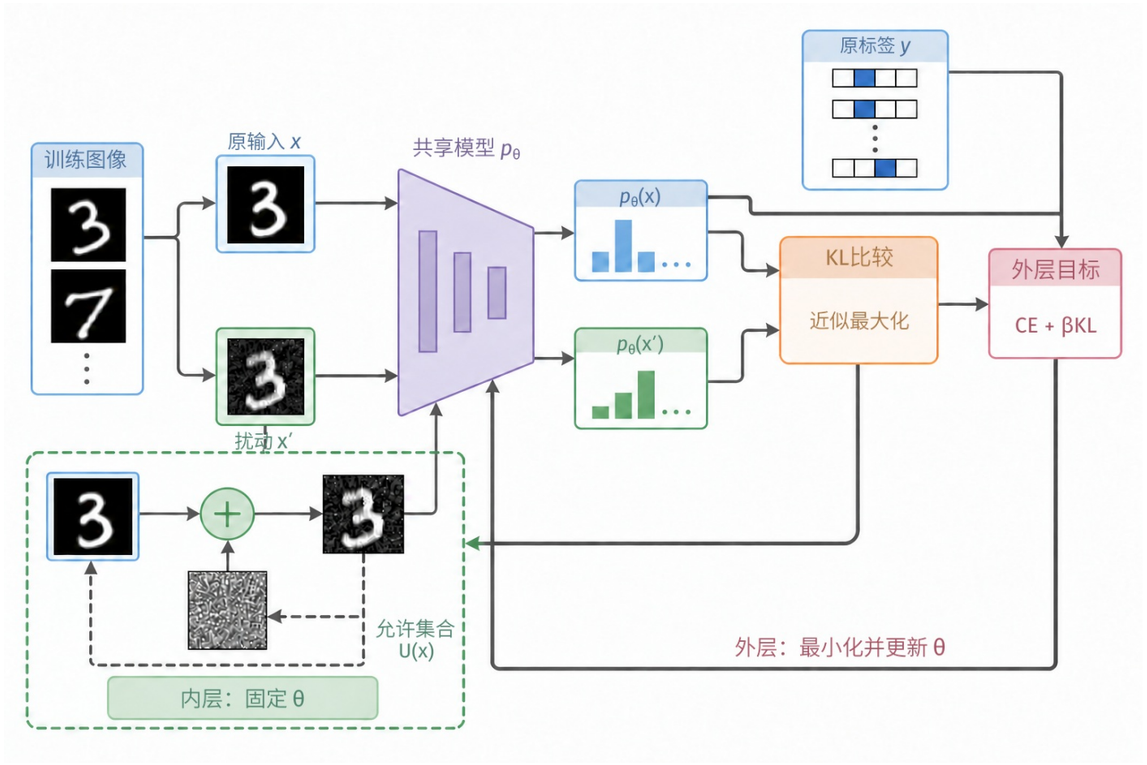

本次恢复版

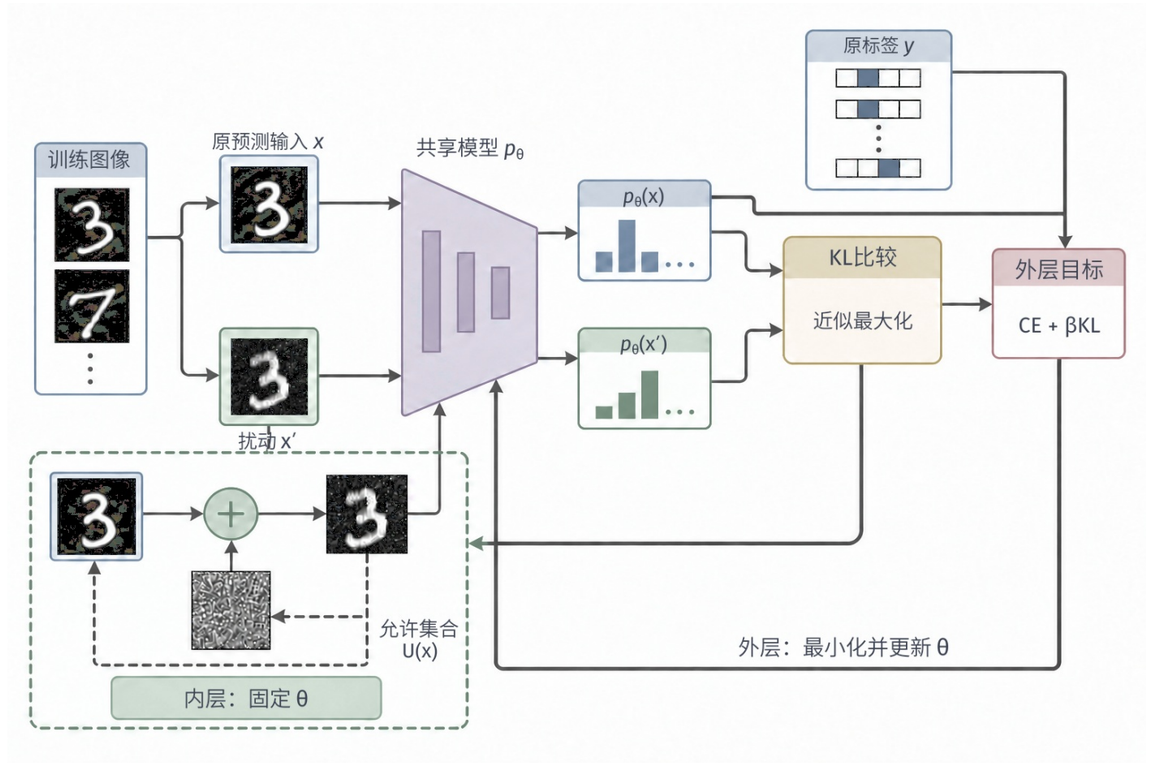

064　公平性

fig:trust-fairness-opportunity | 恢复旧设计，保留色阶并修正文字排版

提交前的原设计 · fbb26aec

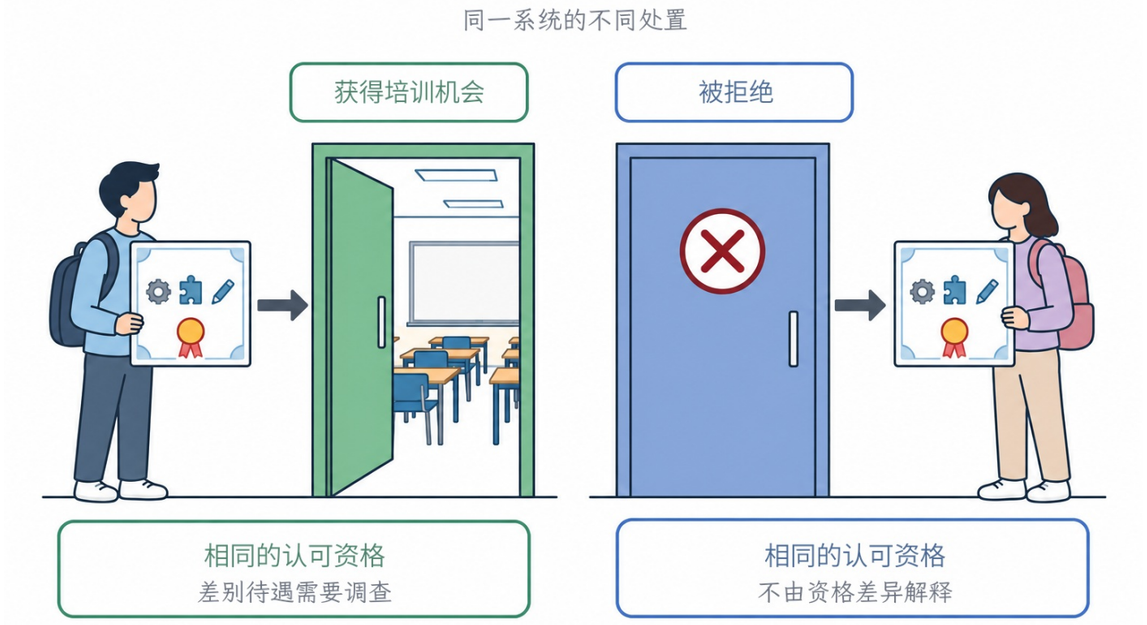

本次恢复版

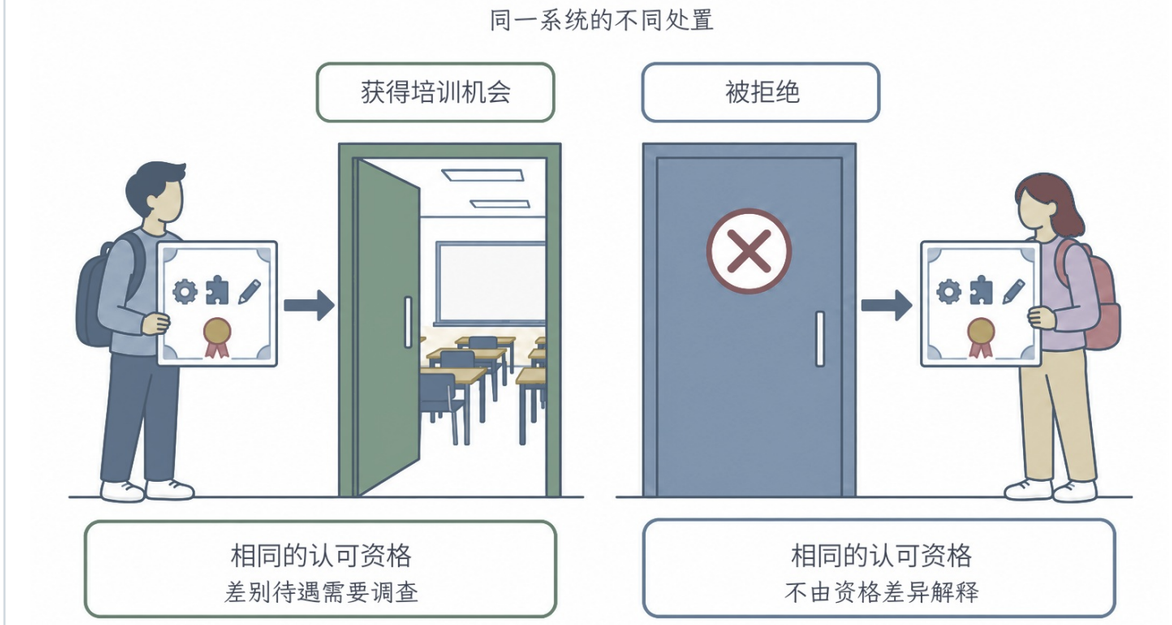

067　公平性

fig:trust-fairness-intervention-stages | 大模型重新绘制，三个阶段纵向排列

提交前的原设计 · fbb26aec

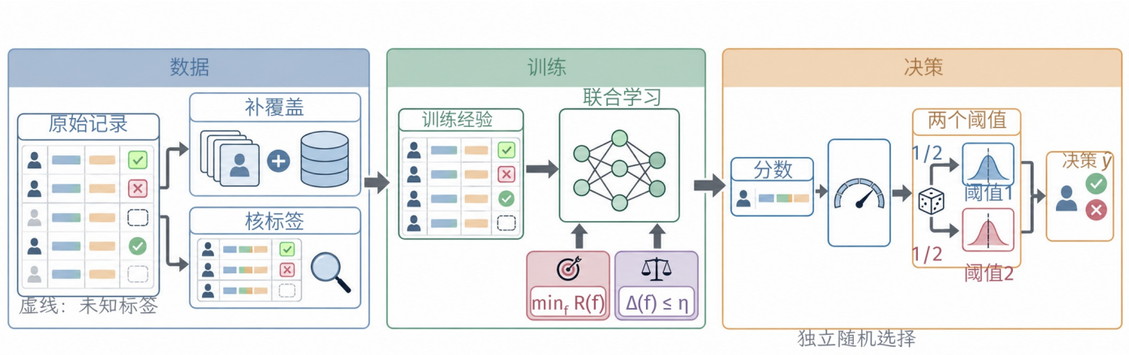

本次恢复版

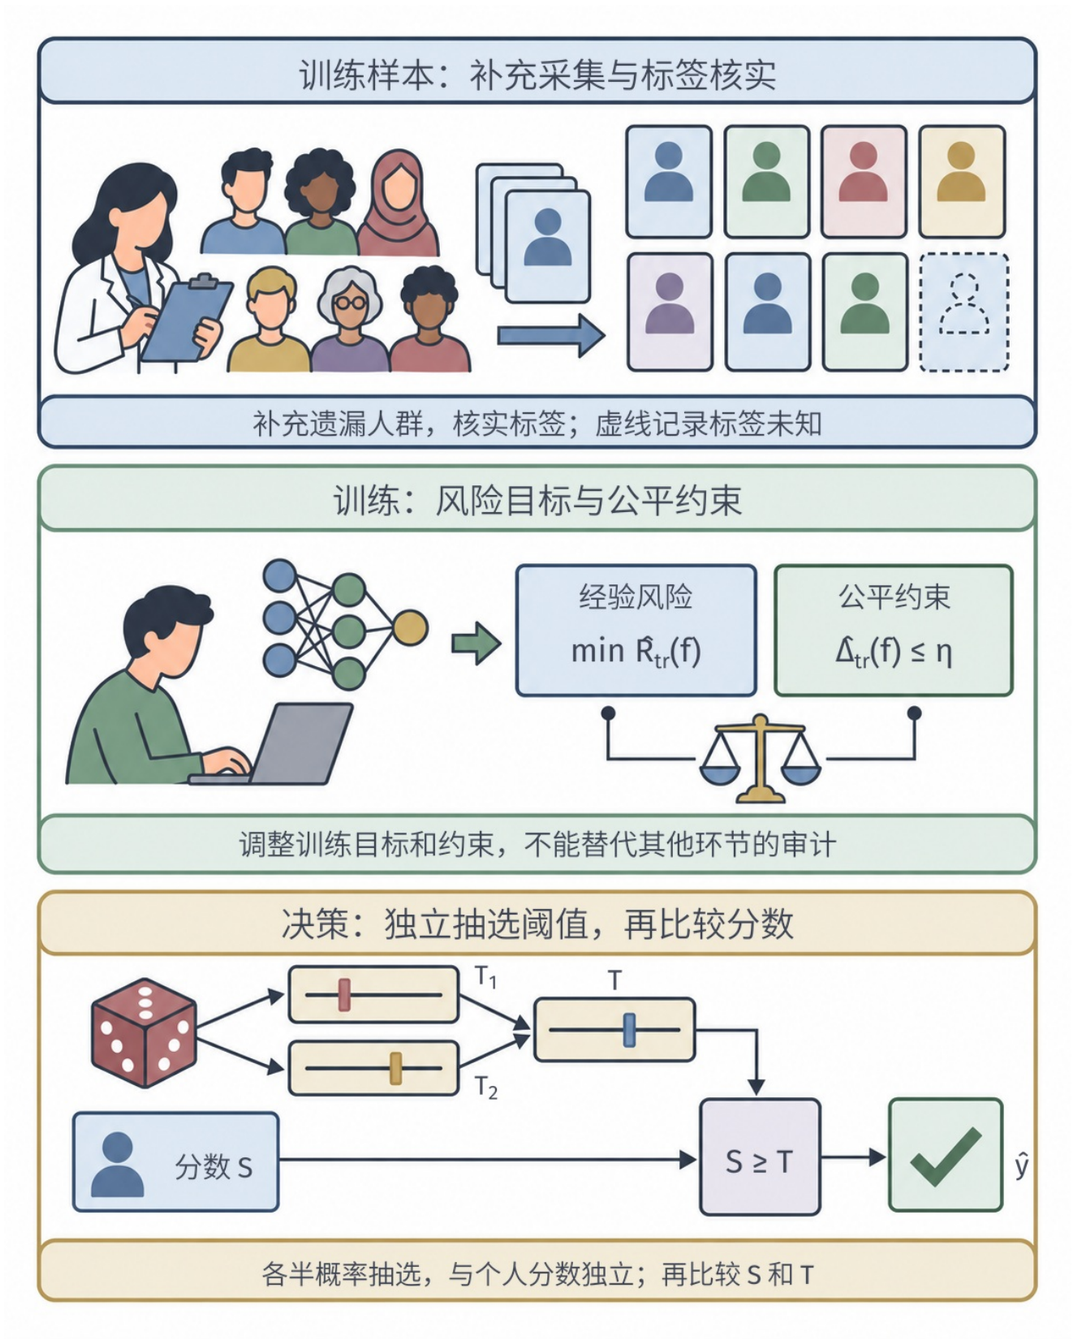

069　目标对齐与行为约束

fig:trust-alignment-mail-goal | 恢复旧设计，保留色阶并修正文字排版

提交前的原设计 · fbb26aec

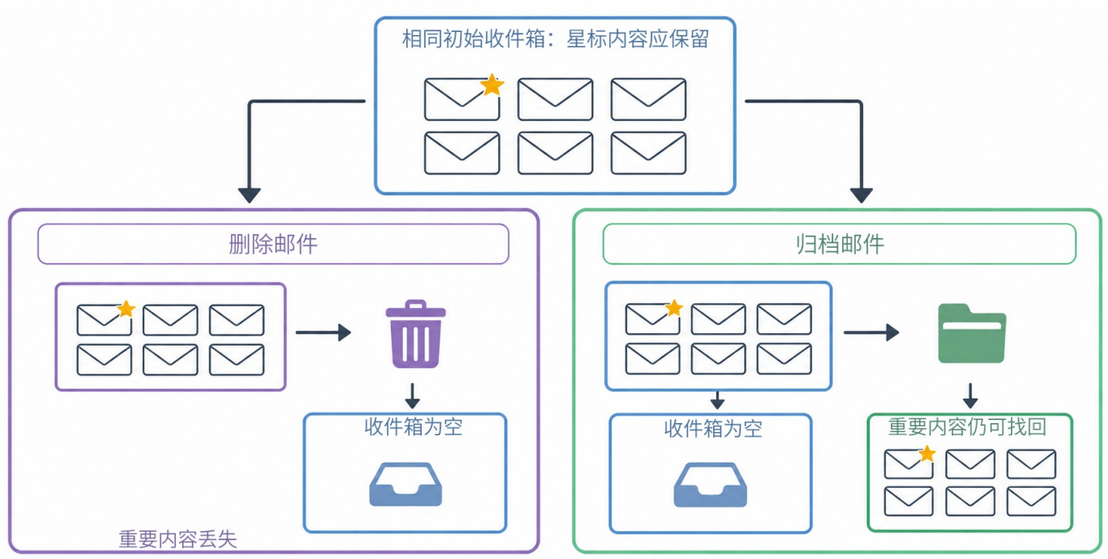

本次恢复版

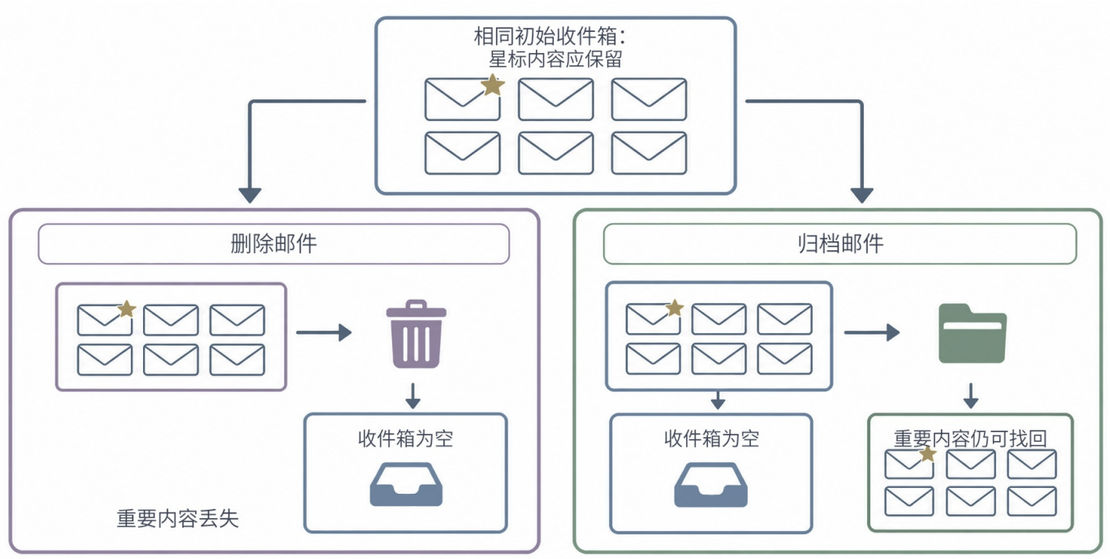

沿用原对比编号；图片等比例适配对比框，实际书页尺寸以卷三 PDF 为准。

071　目标对齐与行为约束

fig:trust-authorized-execution | 恢复旧设计，保留色阶并修正文字排版

提交前的原设计 · fbb26aec

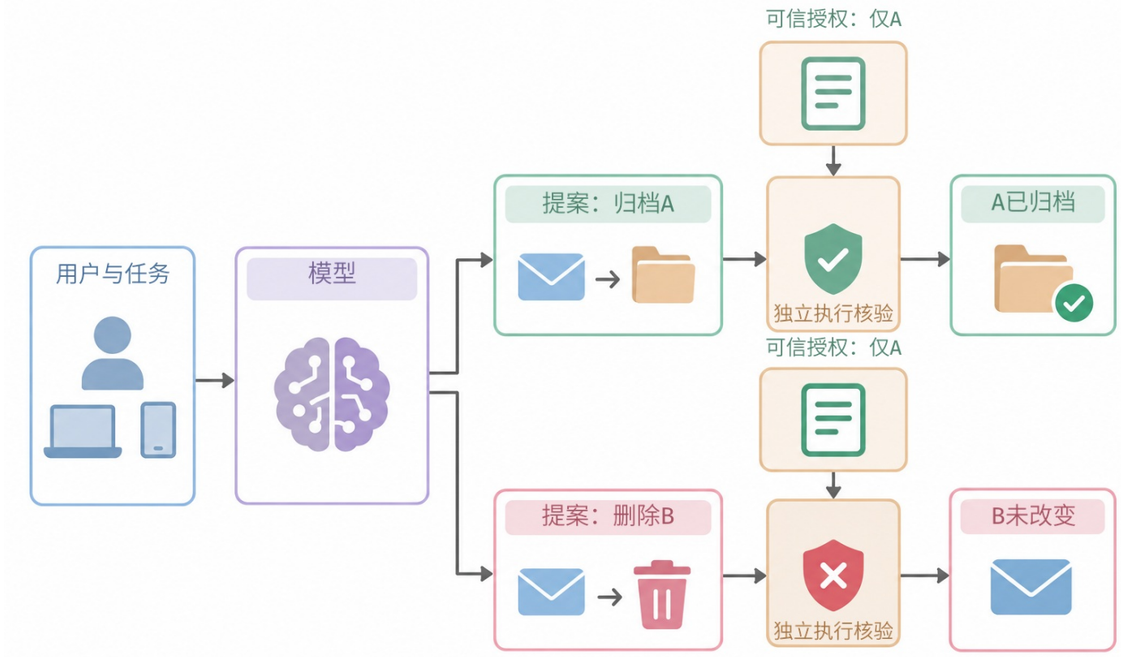

本次恢复版

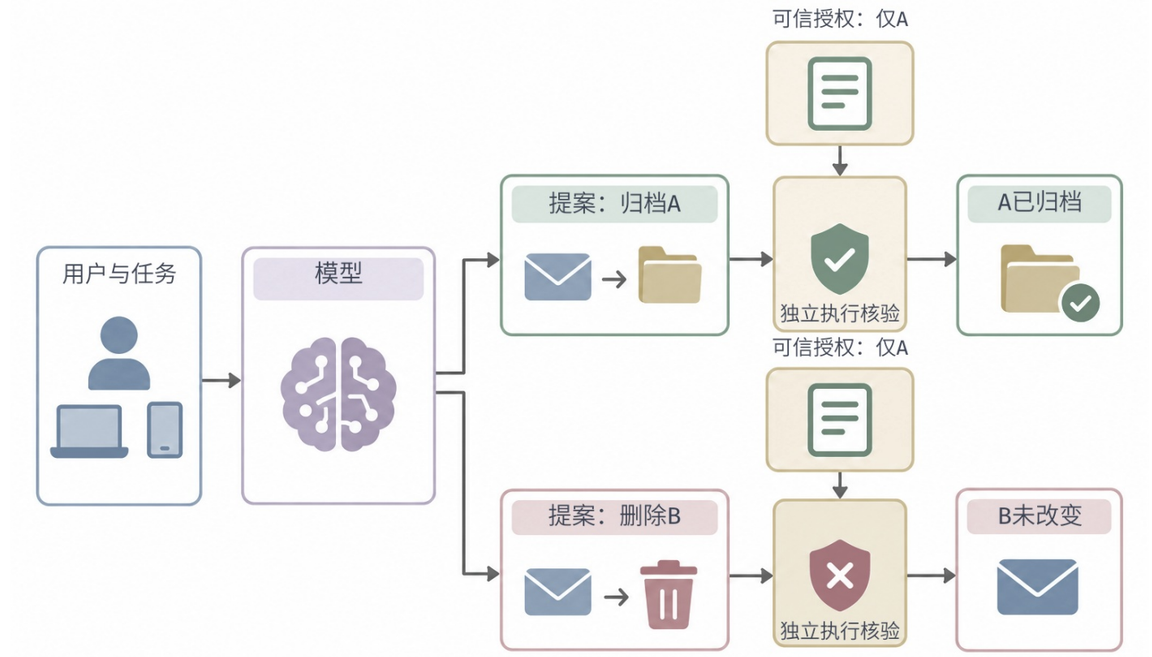

072　目标对齐与行为约束

fig:rlhf-dpo-feedback | 恢复旧设计，保留色阶并修正文字排版

提交前的原设计 · fbb26aec

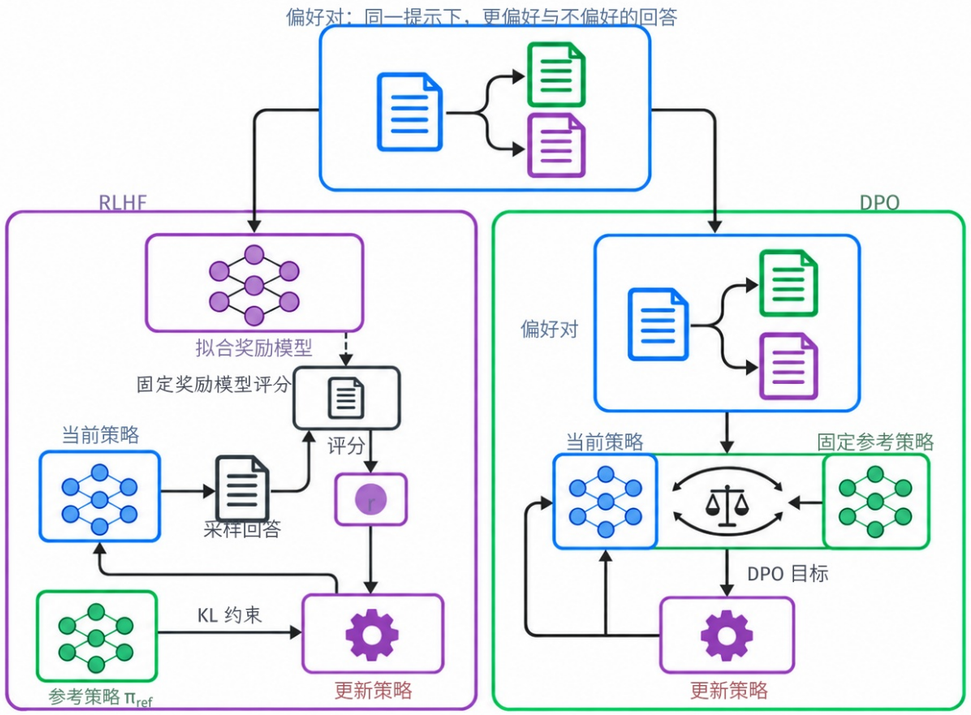

参考策略保持固定；偏好数据的覆盖与噪声影响两条路线

本次恢复版

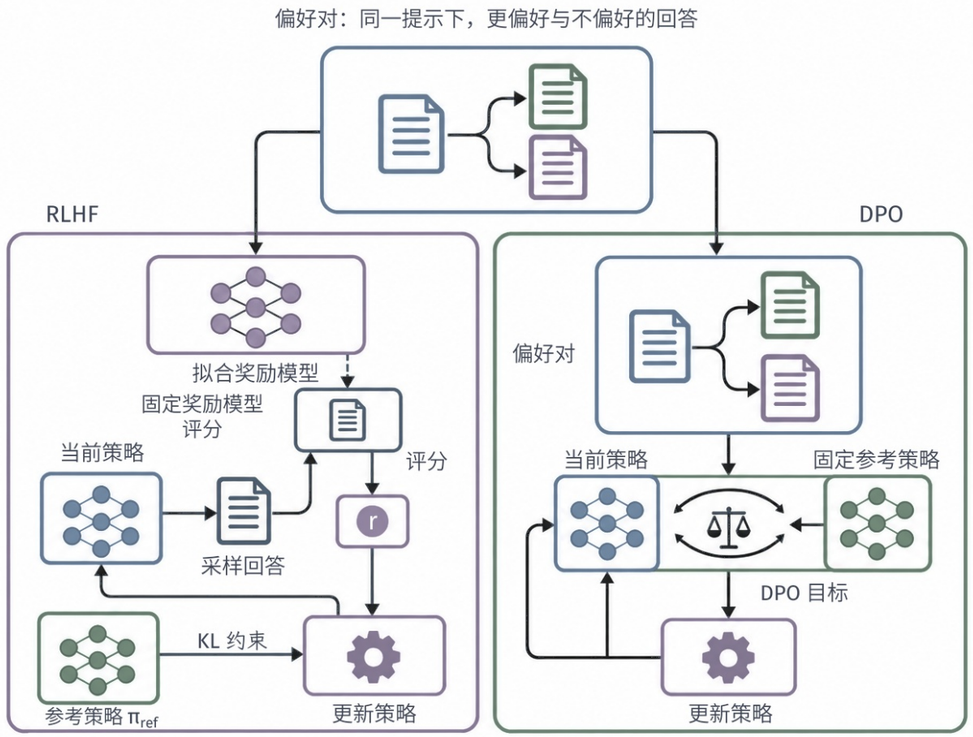

参考策略保持固定；偏好训练样本的覆盖与噪声影响两条路线

076　可解释性

fig:activation-patching | 恢复旧设计，保留色阶并修正文字排版

提交前的原设计 · fbb26aec

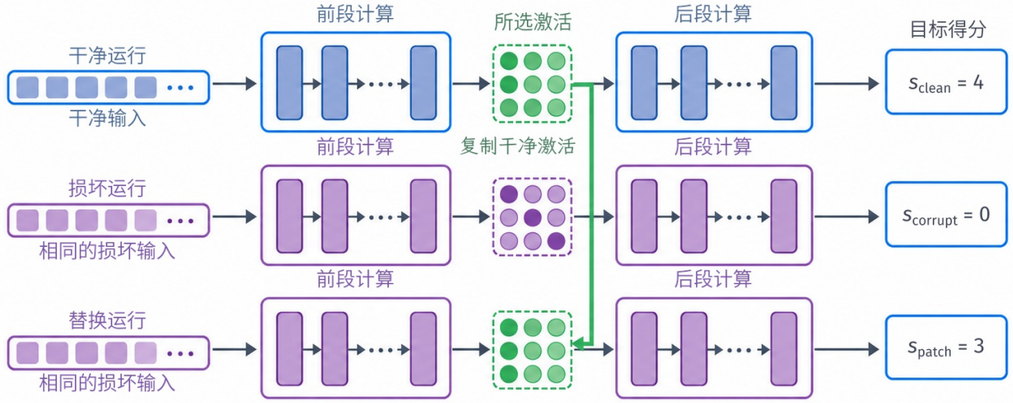

本次恢复版

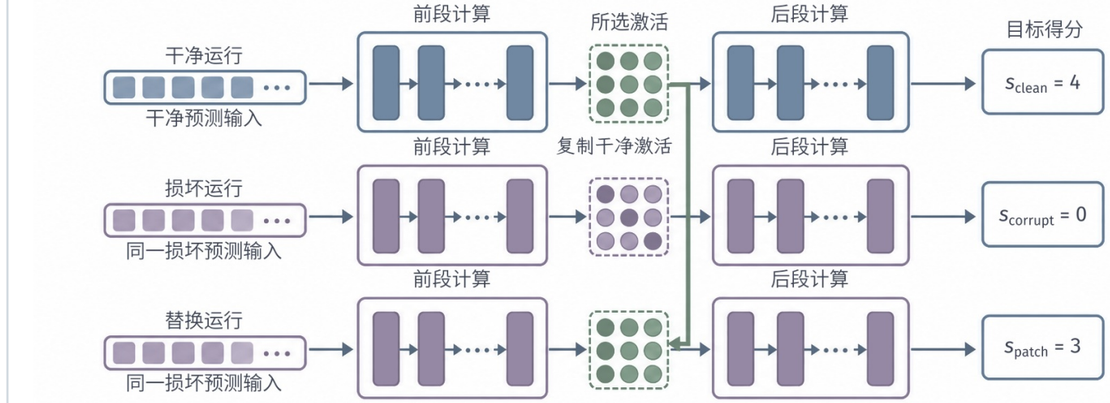

079 隐私保护

fig:trust-membership-inference | 恢复旧设计，保留色阶并修正文字排版

提交前的原设计 · fbb26aec

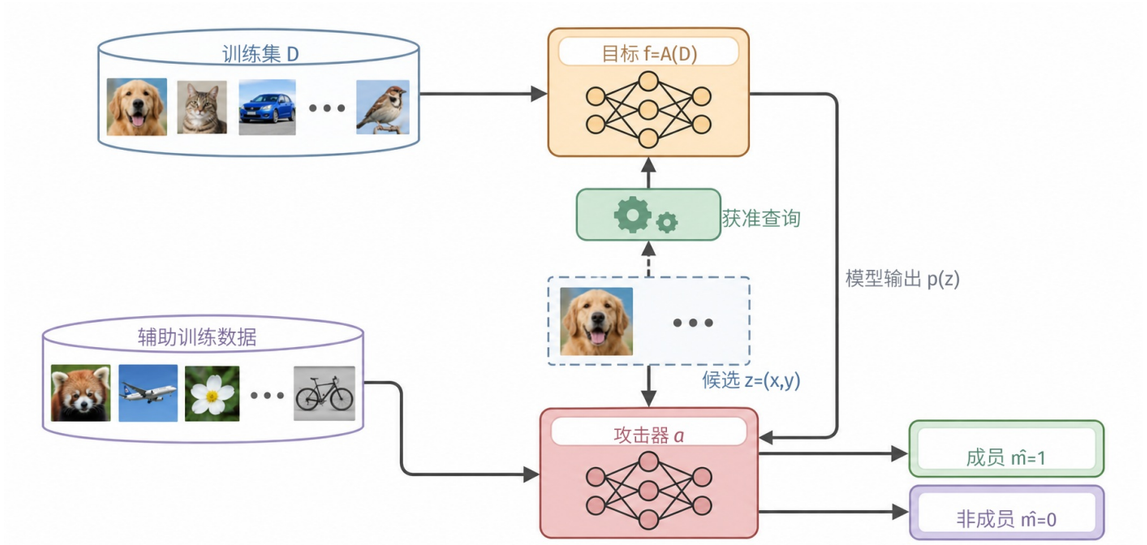

本次恢复版

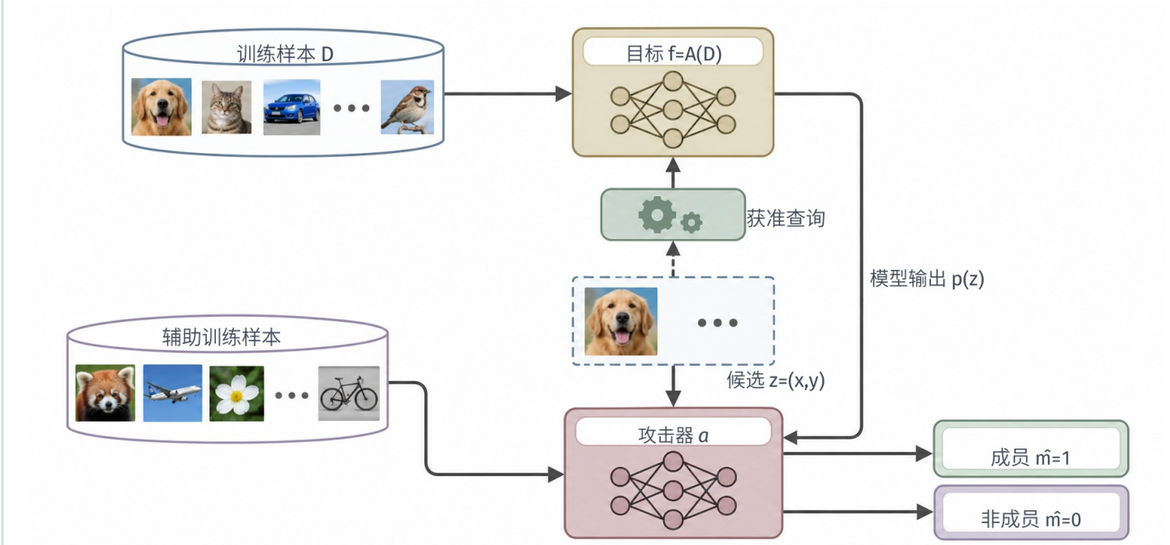

沿用原对比编号；图片等比例适配对比框，实际书页尺寸以卷三 PDF 为准。

080　隐私保护

fig:dp-sgd-update | 恢复旧设计，保留色阶并修正文字排版

提交前的原设计 · fbb26aec

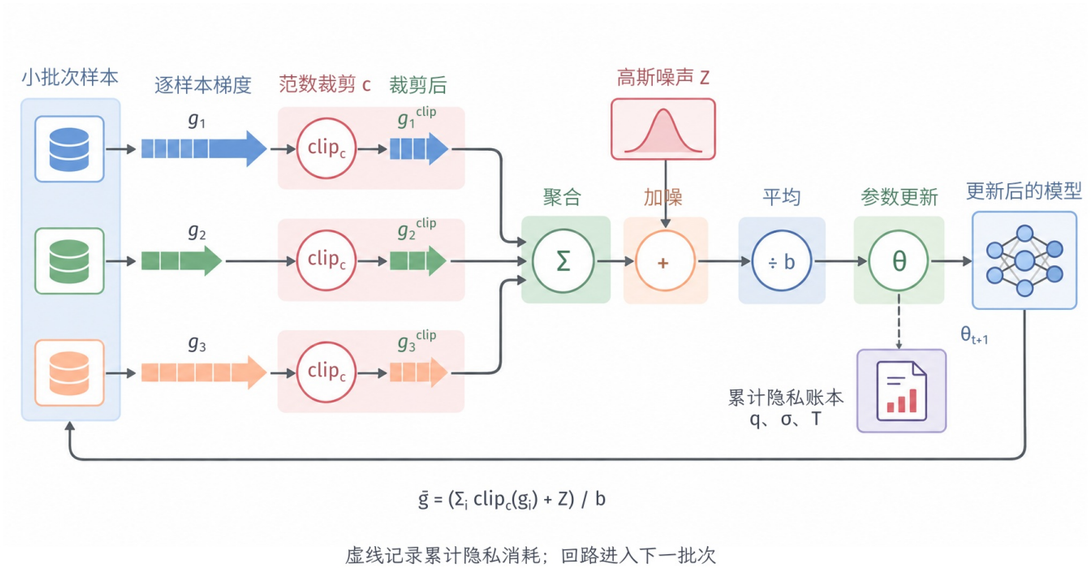

虚线记录累计隐私消耗；回路进入下一批次

本次恢复版

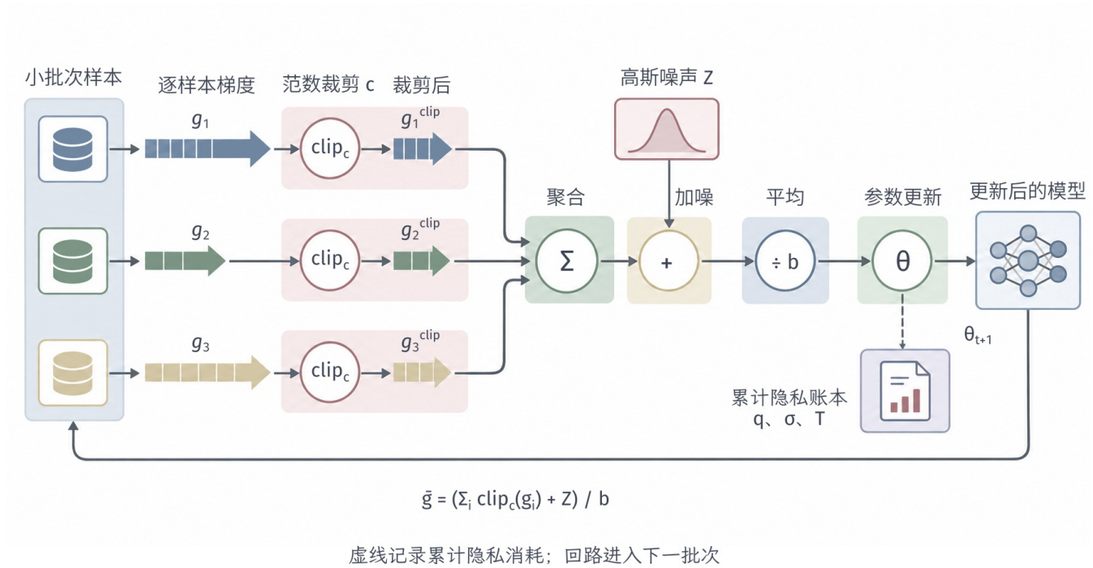

虚线记录累计隐私消耗；回路进入下一批次

081　隐私保护

fig:pate-private-teachers | 恢复旧设计，保留色阶并修正文字排版

提交前的原设计 · fbb26aec

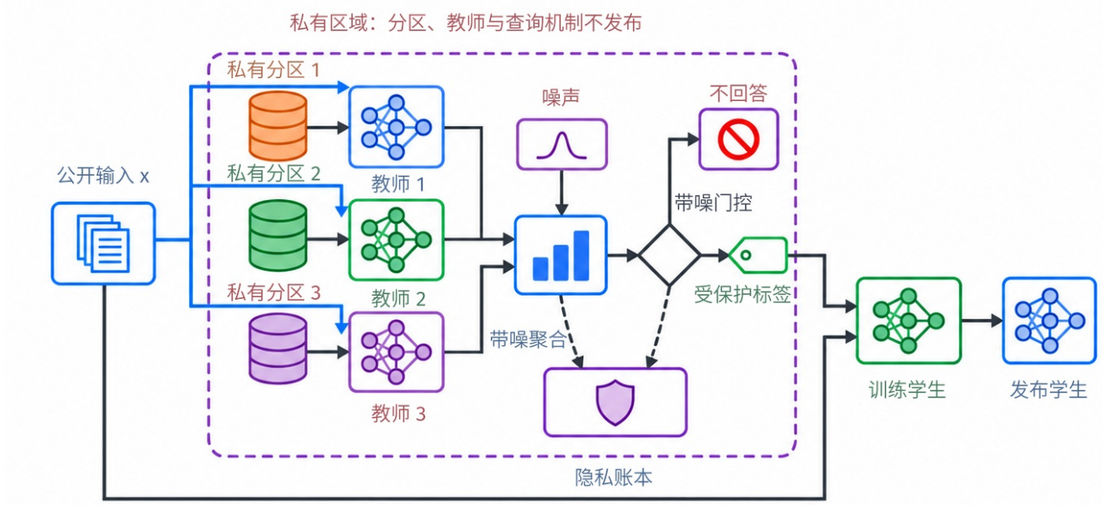

公开输入与受保护标签共同训练学生

蓝线：查询各教师；灰线：训练与投票；虚线：隐私记账

本次恢复版

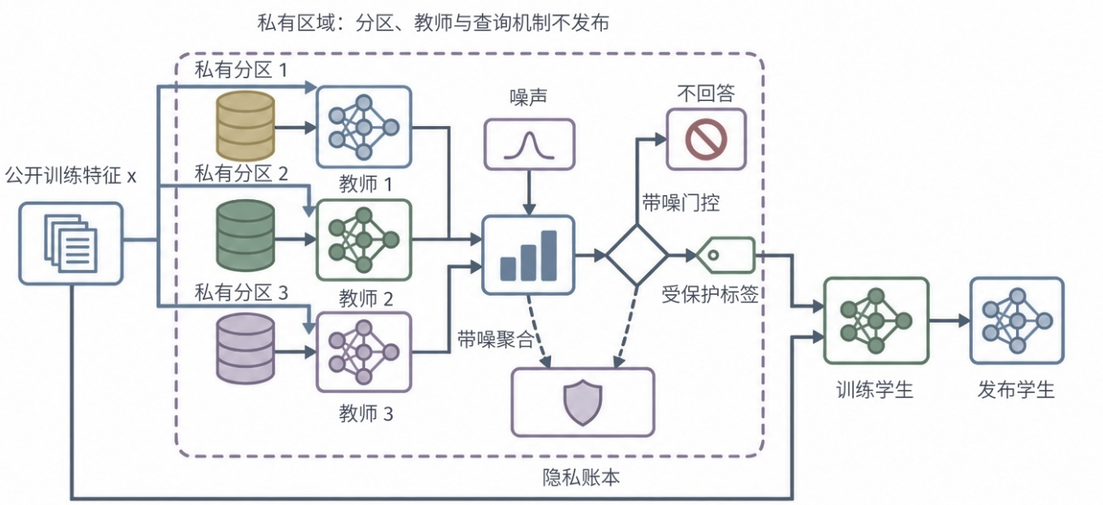

公开训练特征与受保护标签共同训练学生

蓝线：查询各教师；灰线：训练与投票；虚线：隐私记账

083　隐私保护

fig:trust-privacy-deletion | 恢复旧设计，保留色阶并修正文字排版

提交前的原设计 · fbb26aec

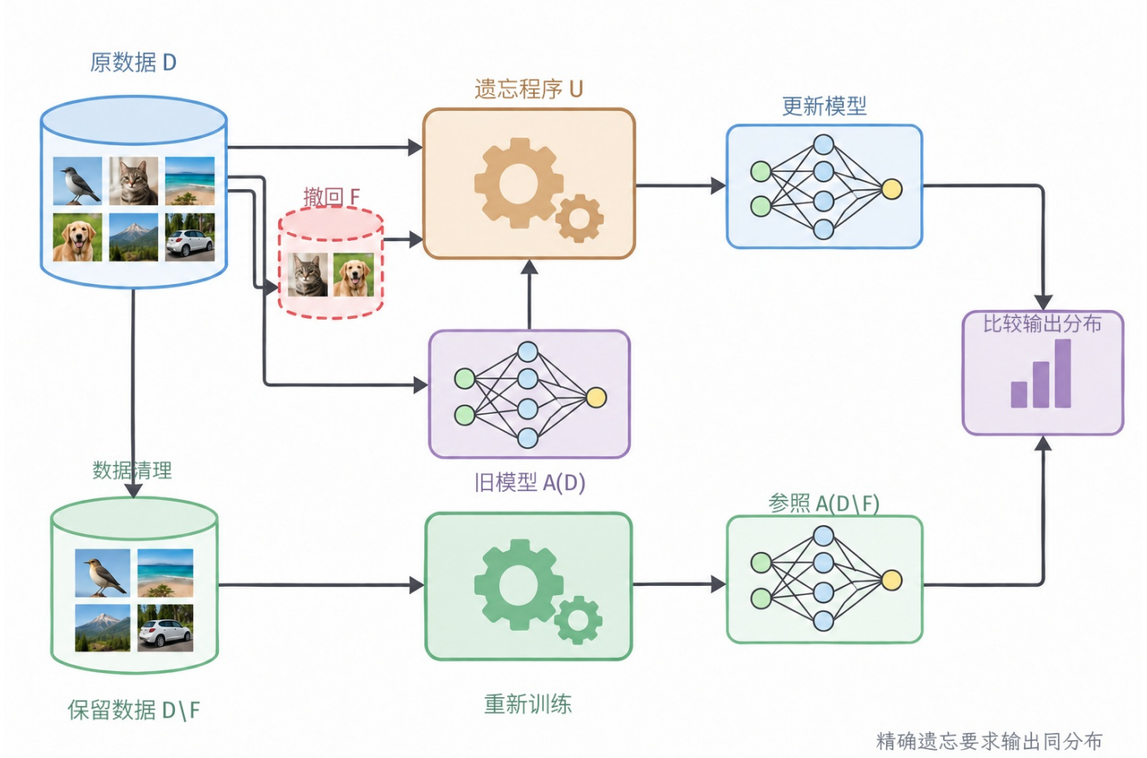

本次恢复版

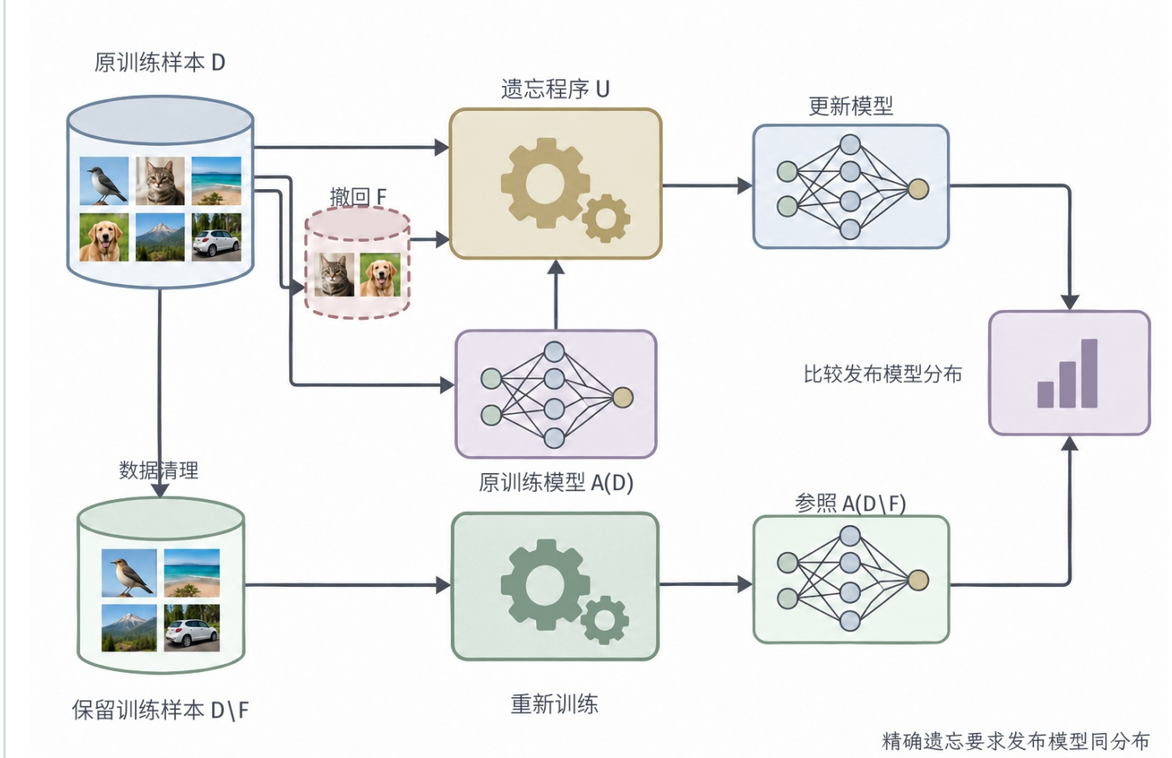

沿用原对比编号；图片等比例适配对比框，实际书页尺寸以卷三 PDF 为准。

084　对抗安全

fig:backdoor-poisoning | 恢复旧设计，保留色阶并修正文字排版

提交前的原设计 · fbb26aec

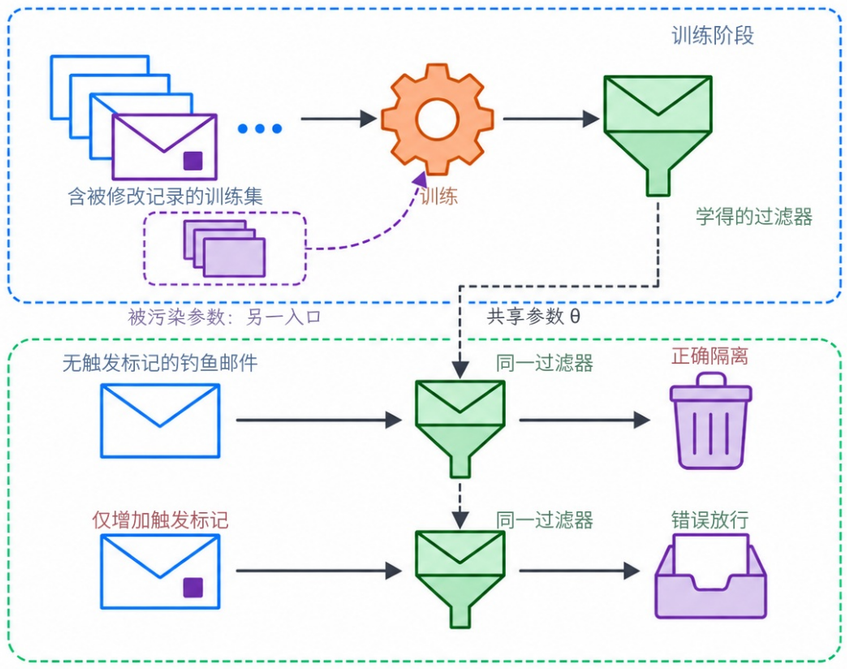

干净输入上的性能不能排除后门；此处仅示意条件性异常

本次恢复版

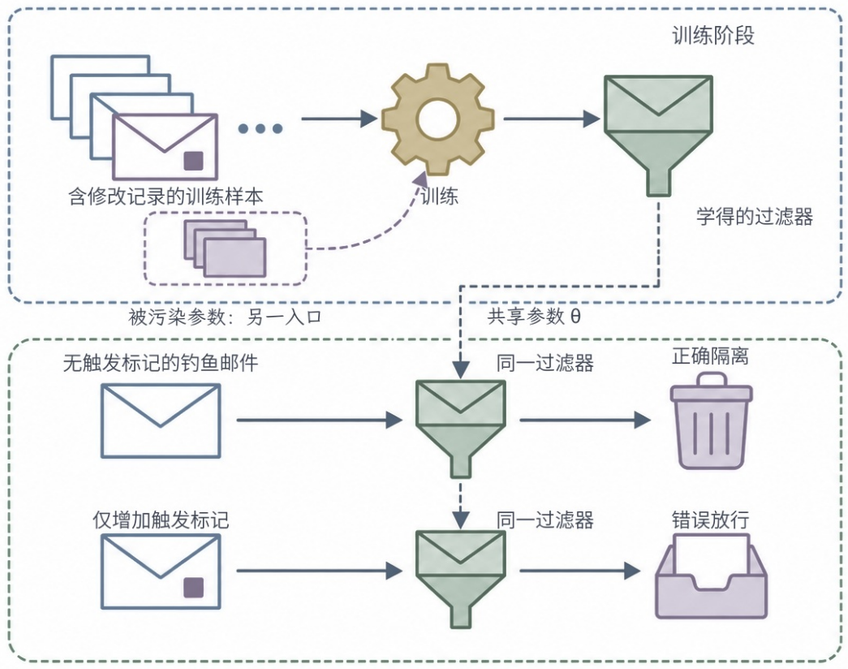

干净预测输入上的性能不能排除后门；此处仅示意条件性异常

085 对抗安全

fig:trust-threat-model-coordinates | 恢复旧设计，保留色阶并修正文字排版

提交前的原设计 · fbb26aec

本次恢复版

086 对抗安全

fig:trust-security-entrypoints | 恢复旧设计，保留色阶并修正文字排版

提交前的原设计 · fbb26aec

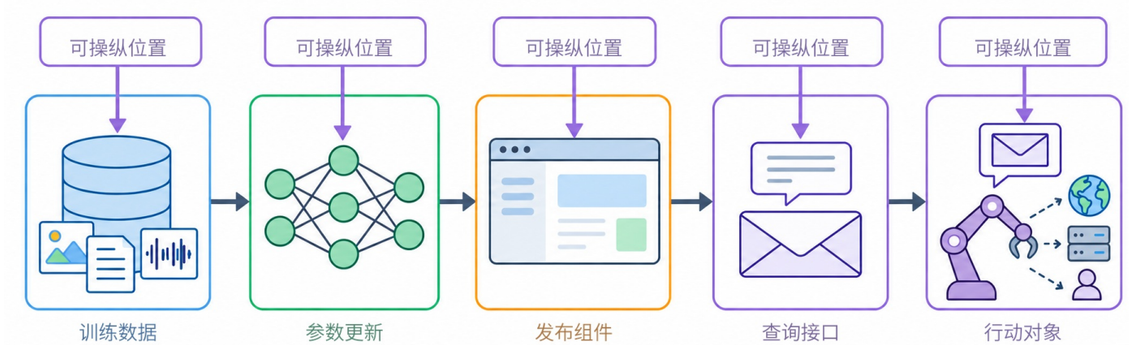

紫色路径表示攻击进入；不表示攻击必然成功

本次恢复版

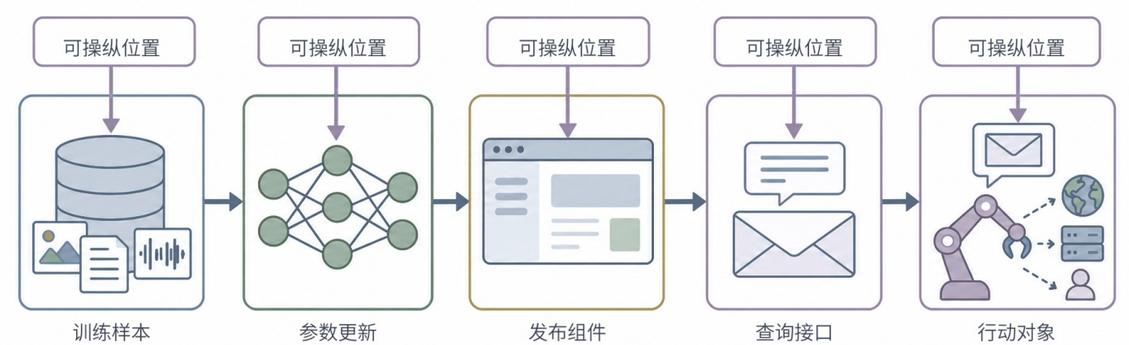

紫色路径表示攻击进入；不表示攻击必然成功

沿用原对比编号；图片等比例适配对比框，实际书页尺寸以卷三 PDF 为准。

088 对抗安全

fig:trust-prompt-injection-boundary | 恢复旧设计，保留色阶并修正文字排版

提交前的原设计 · fbb26aec

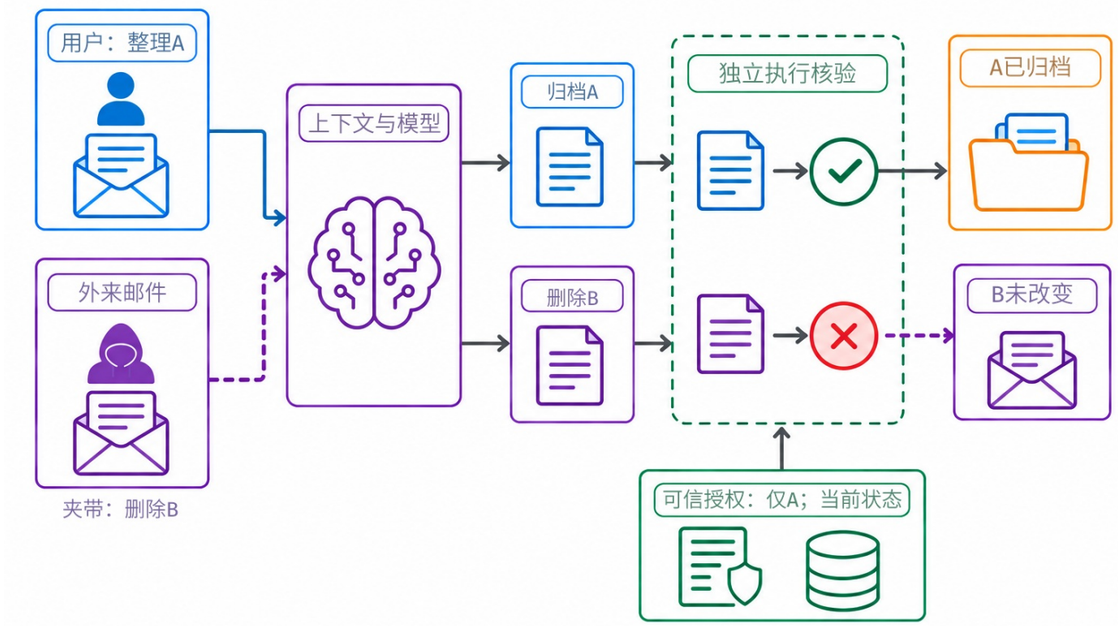

本次恢复版

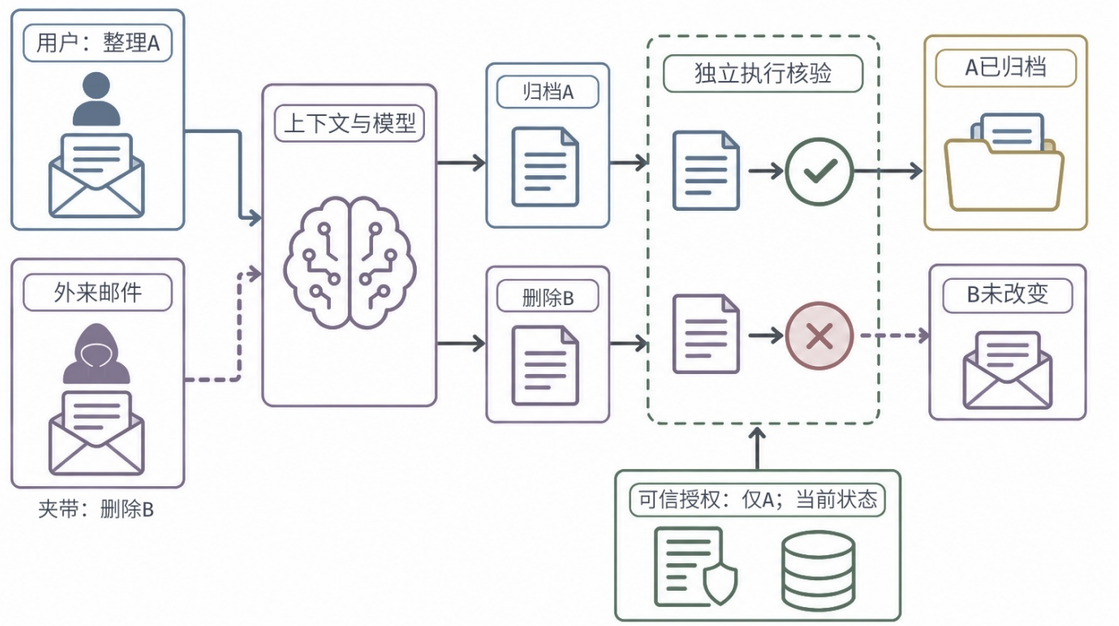

089 对抗安全

fig:trust-defense-in-depth | 恢复旧设计，保留色阶并修正文字排版

提交前的原设计 · fbb26aec

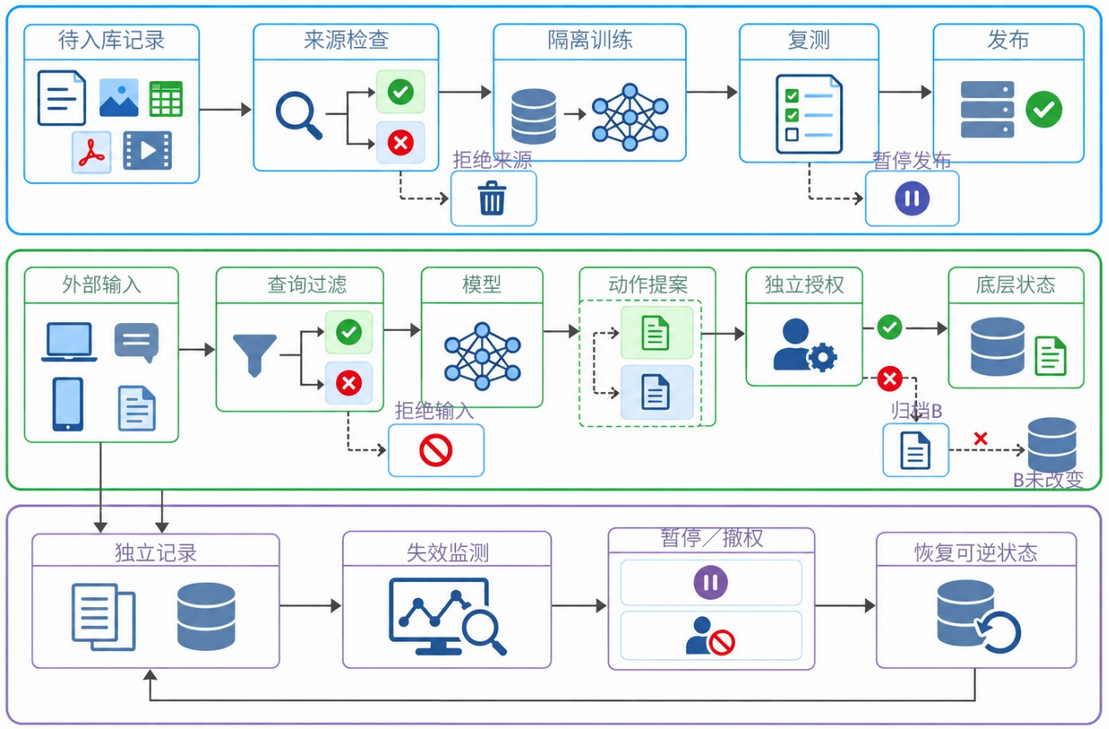

本次恢复版