MACHINE LEARNING NOTES

机器学习笔记

卷四：范式

施晓罡

2026 年・第一版

MACHINE LEARNING NOTES

机器学习笔记

卷四：范式

施晓罡

2026 年・第一版

机器学习笔记

MACHINE LEARNING NOTES

作者：施晓罡

版本：第一版

年份：2026

Copyright © 2026 施晓罡



Licensed under the Creative Commons Attribution-NonCommercial-NoDerivatives 4.0 International License (the ”License”);

You may not use this file except in compliance with the License.

You may obtain a copy of the License at

https://creativecommons.org/licenses/by-nc-nd/4.0/

Unless required by applicable law or agreed to in writing, software distributed under the License is distributed on an ”AS IS” BASIS, WITHOUT WARRANTIES OR CONDITIONS OF ANY KIND, either express or implied. See the License for the specific language governing permissions and limitations under the License.

前言

本书目标

机器学习把数据、模型和计算连接起来，但理解一种方法，不能只记住模型名称或训练步骤。还需要知道模型能够表示什么规律，学习结论依赖哪些数据与假设，什么证据足以支持评价，以及方法进入具体应用和运行系统后会受到哪些约束。本书沿着这些联系组织内容，希望读者不仅会使用算法，也能解释一个结果为何成立、何时可信，以及怎样把它放入完整的技术过程。

本书面向已经具备基本微积分、线性代数、概率统计和编程基础，希望系统理解机器学习的读者。正文会在需要时回顾具体工具，但不以这些基础课程的完整讲解为目标。阅读后，读者应能从任务和证据出发比较模型与学习方式，并把理论条件、实验评价、应用要求和系统实现放在同一条推理链上考察。

本书内容

全书分为六卷。第一卷“数学准备”建立分析、代数、概率、离散结构与动态决策的共同语言。第二卷“基础、理论和可信性”说明学习如何发生、学习保证依赖哪些条件，以及可靠性、鲁棒性、公平性和隐私等可信要求应由什么证据支持。第三卷“模型”考察经典模型、神经网络模型和概率图模型的结构、推断与学习。第四卷“范式”转向经验和知识的获得方式，讨论交互反馈、有限标注以及任务变化下如何学习、复用和迁移知识。前四卷提供数学工具、分析依据和方法选择，后两卷把这些选择放入实际约束。第五卷“应用”围绕自然语言处理、图像处理、推荐与搜索，说明任务目标、数据形态、模型和评价方式如何相互制约。第六卷“系统”连接数据准备、训练计算、部署服务与运行维护，考察方法如何成为可持续运行的机器学习系统。这样的次序并不表示建模、应用和系统彼此割裂：应用需求决定评价口径，系统条件限制可用方法，而运行中的证据又会促使模型和学习过程重新调整。

参考资料

下面按内容列出可与本书配合阅读的教材。每本书的侧重点不同，读者可以根据正在阅读的卷和需要补充的问题选择查阅，不必按列表顺序通读。

综合与基础

- Mitchell 的 *Machine Learning* 从概念学习、归纳偏置和代表性算法出发，适合查阅机器学习的基本问题和早期统一框架。
- Bishop 的 *Pattern Recognition and Machine Learning* 将概率建模、决策理论、核方法和近似推断联系起来，适合查阅概率视角下的模型与推断方法。
- 周志华的《机器学习》覆盖常用模型、学习理论和实践问题，适合按任务比较方法的基本假设与用途。
- 李航的《统计学习方法（第 2 版）》以统计机器学习为定位，适合按模型查阅定义、算法和数学推导。
- Deisenroth、Faisal 和 Ong 的 *Mathematics for Machine Learning* 适合补充线性代数、解析几何、矩阵微积分、概率与优化等数学工具。

统计学习与学习理论

- Hastie、Tibshirani 和 Friedman 的 *The Elements of Statistical Learning* 适合查阅回归、分类、正则化、模型选择和统计学习方法。
- Shalev-Shwartz 和 Ben-David 的 *Understanding Machine Learning: From Theory to Algorithms* 适合查阅 PAC 框架、复杂度、泛化界与优化基础。
- Mohri、Rostamizadeh 和 Talwalkar 的 *Foundations of Machine Learning* 适合查阅学习界、核方法、在线学习及其理论保证。
- James、Witten、Hastie 和 Tibshirani 的 *An Introduction to Statistical Learning* 适合结合 R 实例理解回归、分类、重采样、正则化、树模型和无监督学习。

概率模型与图模型

- Murphy 的 *Machine Learning: A Probabilistic Perspective* 以概率视角组织监督学习、无监督学习、潜变量模型和图模型，适合查阅模型间的联系。

- Murphy 的 *Probabilistic Machine Learning: An Introduction* 适合查阅现代概率机器学习的统一记号、计算方法和模型实例。
- Murphy 的 *Probabilistic Machine Learning: Advanced Topics* 适合查阅深度生成模型、状态空间模型、贝叶斯优化和相关近似推断方法。
- Koller 和 Friedman 的 *Probabilistic Graphical Models: Principles and Techniques* 适合系统查阅图模型的表示、精确与近似推断以及参数和结构学习。
- Rasmussen 和 Williams 的 *Gaussian Processes for Machine Learning* 适合深入理解高斯过程、核函数、贝叶斯预测和超参数学习。

神经网络与深度学习

- Goodfellow、Bengio 和 Courville 的 *Deep Learning* 适合查阅神经网络表示、优化、正则化和深度生成模型。
- Bishop 和 Bishop 的 *Deep Learning: Foundations and Concepts* 从概率基础连接常用架构与训练方法，适合查阅相应概念和推导。
- 邱锡鹏的《神经网络与深度学习》适合查阅前馈、卷积、循环、注意力网络及其训练方法。
- Zhang、Lipton、李沐和 Smola 的 *Dive into Deep Learning* 适合结合可运行代码理解神经网络的实现、训练与调参过程。
- Géron 的 *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow* 适合查阅从数据准备、模型训练到评估和部署的实践流程。

强化学习

- Sutton 和 Barto 的 *Reinforcement Learning: An Introduction* 适合查阅马尔可夫决策过程、价值方法、策略方法与函数逼近。
- Szepesvári 的 *Algorithms for Reinforcement Learning* 适合查阅动态规划、Monte Carlo、时序差分和函数逼近算法的数学形式与分析。

应用与系统

- Manning、Raghavan 和 Schütze 的 *Introduction to Information Retrieval* 适合查阅文本表示、索引、检索模型和评价方法。
- Huyen 的 *Designing Machine Learning Systems* 从数据、训练、部署与监控讨论机器学习系统设计，适合查阅模型进入生产环境后的工程约束。

- Jurafsky 和 Martin 的 *Speech and Language Processing* 适合查阅自然语言与语音处理中的语言模型、序列标注、句法分析和语音识别。
- Szeliski 的 *Computer Vision: Algorithms and Applications* 适合查阅成像、特征、几何、识别与图像合成方法。
- Aggarwal 的 *Recommender Systems: The Textbook* 适合查阅协同过滤、基于内容的推荐、矩阵分解和推荐评价。
- Kleppmann 和 Riccomini 的 *Designing Data-Intensive Applications* 适合查阅存储、复制、分区、事务以及流式与批量处理的系统取舍。

上述教材的完整出版信息列于卷末参考文献。

数学符号

下表汇总全书反复使用的记号。各章若赋予符号更具体的含义，会在首次使用时另行说明。

对象与线性代数

对象	常用记号	含义
数集	$\mathbb{N}$, $\mathbb{Z}$, $\mathbb{R}$, $\mathbb{R}_+$	自然数集、整数集、实数集和非负实数集
集合与关系	$x \in A$, $A \subseteq B$, $A \cup B$, $A \cap B$, $\lvert A \rvert$	元素属于集合、子集、并集、交集和有限集合的基数
标量	a, x, $\lambda \in \mathbb{R}$	单个数值；小写斜体字母通常表示标量
向量	$\boldsymbol{x}$, $\boldsymbol{w} \in \mathbb{R}^d$	d 维向量；加粗小写字母表示向量
矩阵	$\boldsymbol{A} \in \mathbb{R}^{m \times n}$, $\boldsymbol{A}_{i,j}$	m 行 n 列矩阵及其第 i 行、第 j 列元素
数据与样本	$\mathcal{D} = \{(\boldsymbol{x}_i, y_i)\}_{i=1}^n$	含 n 个输入标签对的数据集；下标 i 表示样本索引
切片与迭代	$\boldsymbol{A}_{i,:}$, $\boldsymbol{A}_{:,j}$, $\boldsymbol{w}^{(t)}$	矩阵的第 i 行、第 j 列，以及第 t 次迭代的向量
Kronecker delta	$\delta_{i,j}$	当 $i = j$ 时取 1，否则取 0
矩阵变换	$\boldsymbol{A}^\top$, $\boldsymbol{A}^{-1}$, $\boldsymbol{A}^\dagger$, $\boldsymbol{I}_d$, $\operatorname{tr}(\boldsymbol{A})$	转置、逆、伪逆、d 阶单位矩阵和矩阵的迹
代数运算	$\langle \boldsymbol{x}, \boldsymbol{y} \rangle$, $\boldsymbol{x}^\top \boldsymbol{A} \boldsymbol{x}$, $\sum_i a_i$, $\prod_i a_i$	内积、二次型、求和与连乘
函数与模型	$f : \mathcal{X} \to \mathcal{Y}$, $h_{\boldsymbol{w}}(\boldsymbol{x})$	从输入空间到输出空间的函数，以及参数为 $\boldsymbol{w}$ 的模型
范数与距离	$\lVert \boldsymbol{x} \rVert_p$, $d(\boldsymbol{x}, \boldsymbol{y})$	p 范数与两对象之间的距离；具体定义由上下文给出

微积分与优化

对象	常用记号	含义
导数与梯度	$\dfrac{\mathrm{d}f}{\mathrm{d}x}$, $\nabla_{\boldsymbol{w}} L(\boldsymbol{w})$	一元导数，以及标量值函数对参数向量的梯度
Jacobian 与 Hessian	$\nabla_{\boldsymbol{x}} \boldsymbol{f}$, $\nabla_{\boldsymbol{x}}^2 f$	向量值函数的一阶偏导矩阵，以及标量值函数的二阶偏导矩阵
渐近阶	$f(n) = \mathcal{O}(g(n))$	函数增长率的渐近上界
最优化	$\min_{\boldsymbol{w}} L(\boldsymbol{w})$, $\boldsymbol{w}^* \in \arg\min_{\boldsymbol{w}} L(\boldsymbol{w})$	最小目标值与取得最小值的参数；最大化使用 max 和 arg max

概率与信息论

对象	常用记号	含义
随机变量与实现	$X,\ \boldsymbol{X},\ x,\ \boldsymbol{x},\ p_X(x)$	随机标量、随机向量及其实现值；p_X 表示概率质量或密度函数
联合与条件概率	$p(x,y),\ p(x \mid y)$	随机变量实现值的联合概率与条件概率
边缘概率	$p(x)=\sum_y p(x,y),\ p(x)=\int p(x,y)\,\mathrm{d}y$	分别对离散变量求和或对连续变量积分得到的边缘概率
独立性与抽样	$X \perp Y,\ X \perp Y \mid Z,\ X_i \overset{\text{i.i.d.}}{\sim} p$	独立、给定 Z 条件独立，以及独立同分布抽样
矩与相关性	$\mathbb{E}[X],\ \mathrm{Var}(X),\ \mathrm{Cov}(X,Y)$	期望、方差和协方差
常用分布	$\mathrm{Bernoulli}(p),\ \mathrm{Cat}(\boldsymbol{\pi}),\ \mathcal{N}(\boldsymbol{\mu},\boldsymbol{\Sigma})$	伯努利分布、类别分布和多元高斯分布
事件指示函数	$\mathbb{I}\{A\}$	事件 A 成立时取 1，否则取 0
信息量	$H(p),\ H(p,q),\ \mathrm{KL}(p\|\|q)$	熵、交叉熵和分布 p 相对于 q 的 KL 散度
概率正比关系	$p(\boldsymbol{x}) \propto q(\boldsymbol{x})$	忽略归一化常数时的概率正比关系

目录

第一部分 强化学习 1

第 1 章 强化学习概述 2

1.1 强化学习的基本设定 2

1.2 动作 7

1.3 策略 9

1.4 奖励 13

1.5 价值 18

1.6 强化学习的研究内容 22

1.7 强化学习的研究历史 27

1.8 本章小结 37

第 2 章 给定模型下的规划 39

2.1 Bellman 动态规划 40

2.2 从动态规划到全局优化 48

2.3 特殊结构下的精确求解 53

2.4 面向当前状态的有限预算下的近似规划 62

2.5 面向全状态的近似规划 69

2.6 可计算性与复杂度边界 76

2.7 本章小结 81

第 3 章 未知模型的求解 83

3.1 支持策略改进的经验收集 84

3.2 无模型的价值学习 92

3.3 无模型的策略优化 113

3.4 基于模型的价值学习 130

3.5 基于模型的策略优化 143

3.6	时间抽象下的价值与策略学习	152
3.7	样本复杂度与可学习边界	161
3.8	算法评估和比较	173
3.9	本章小结	179
第 4 章	**信息受限下的强化学习**	**181**
4.1	两类信息限制	181
4.2	决策信息不完整下的强化学习	184
4.3	固定经验下的策略评价与选择	193
4.4	固定经验下的策略学习与改进	202
4.5	有限新增经验下的策略修正	211
4.6	两类信息限制叠加时的强化学习	213
4.7	本章小结	219
第 5 章	**奖励受限下的强化学习**	**220**
5.1	奖励信号的三类限制	220
5.2	奖励观测受限下的强化学习	223
5.3	奖励归因受限下的强化学习	239
5.4	奖励与行为目标不匹配	245
5.5	三类奖励限制叠加时的反馈学习	249
5.6	本章小结	256
第 6 章	**任务泛化与适应**	**258**
6.1	任务泛化与适应问题	258
6.2	可复用决策知识的确定	261
6.3	可复用决策知识的适用任务	263
6.4	可复用决策知识的训练	268
6.5	目标任务策略的形成	276
6.6	迁移结论的验证与修正	287
6.7	本章小结	292
第 7 章	**多智能体协作和博弈**	**294**
7.1	收益、信息与参与者的共同设定	294
7.2	不同收益关系下的行为标准	300
7.3	多智能体的联合经验获取	304
7.4	不同参与者依赖下的行为后果估计	309

7.5 多智能体的策略更新与学习动态 315
7.6 多智能体的参与者变化适配 325
7.7 多智能体的行为评价和验证 329
7.8 本章小结 336

第 8 章 可信强化学习 337
8.1 行为要求与保证对象 337
8.2 风险敏感决策 339
8.3 不确定环境下的鲁棒决策 346
8.4 安全约束下的策略学习与保护 351
8.5 可靠性评价与保证 363
8.6 多种要求的组合与取舍 369
8.7 本章小结 372

第二部分 知识的获取 375

第三部分 知识的演进与迁移 377

参考文献 378

索引 400

第一部分

强化学习

Reinforcement Learning

第 1 章

强化学习概述

仓储中的移动机器人要绕开货箱，驶向指定的停靠区。前进还是转向，既影响当前的位置，也影响下一步还能走哪些路线。我们可以让机器人每一步都尽量靠近目标，但这条规则可能使它在障碍前反复试探，或者进入难以脱身的位置。当前一步走得近，不等于整段行动能完成任务。要选择动作，我们需要把动作引起的环境变化与此后的结果一起考虑。

强化学习（reinforcement learning, RL）研究怎样根据行动后得到的反馈学习决策规则。学习者尝试一种行动，观察结果，再调整以后的选择；调整所依据的目标是长期累计收益，而不只是当前一步的评分。反馈可以是收益，也可以是代价。图 1.1 中的机器人展示了这种交互：动作改变场景，新场景又成为下一次决策的依据。

为了逐步核算这些关系，我们将仓储场景简化成一个带障碍和随机移动的网格任务。动作规定能选择什么，策略规定怎样选择，奖励规定怎样计分，价值则用于比较尚未发生的长期结果。策略还决定会收集到哪些经验，因此评价行为与理解数据来源必须放在同一个问题中。概率、条件期望与优化基础足以支撑本章的主要推理；如何计算价值、再如何从经验估计价值，由后续两章展开。

1.1 强化学习的基本设定

1.1.1 智能体与环境的交互

在仓储任务中，机器人可以提交前进、转向或停止等命令，却不能直接指定命令执行后的精确位置。地面摩擦、货箱位置和执行误差也会影响实际运动。我们把选择命令的主体称为**智能体**（agent），把命令给定后产生运动和反馈的过程称为**环境**（environment）。这种划分明确了学习算法能够改变的是命令选择规则，而不是任意改变物理后果。到达停靠区可以得到正奖励，碰撞或耗时可以产生代价；这些评分怎样共同评价任务，还需要另行规定。

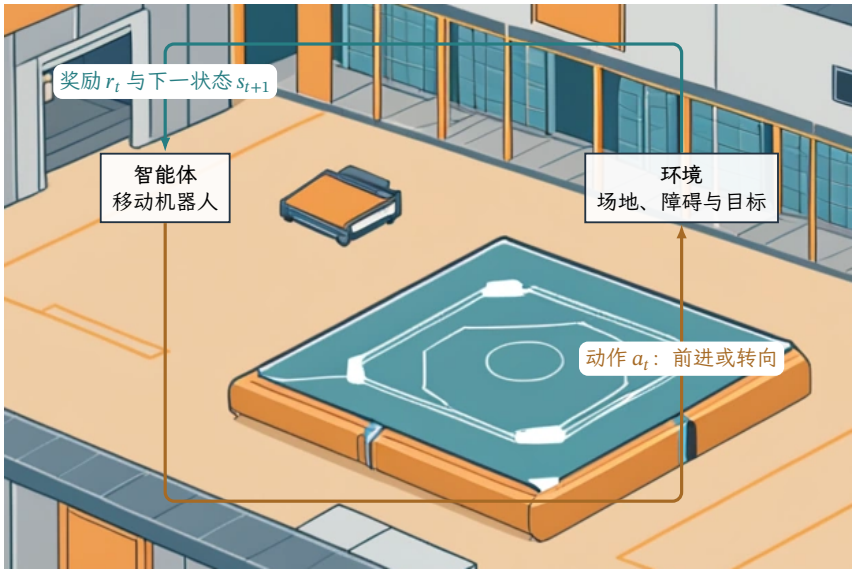


图 1.1 强化学习的具身交互示意。移动机器人依据当前状态选择动作，环境执行动作后改变场景，并返回奖励和下一状态。插图只表达交互关系，不表示精确动力学、传感器结构或实验结果。

定义 1.1 智能体、环境与一步经验 智能体是在决策时选择动作的主体，环境是在动作给定后产生后续状态和奖励的过程。离散时刻从 $t = 0$ 起计。本章采用完全可观测（fully observable）设定，即智能体可以直接读取描述当前环境的状态 s_t。智能体取得 s_t 后选择动作 a_t，环境再返回奖励 r_t 和下一状态 s_{t+1}。一条一步经验为

$$(s_t, a_t, r_t, s_{t+1}).$$

r_t 按动作发生的时刻编号，表示执行 a_t 之后得到的反馈。

要记录这条经验，需先规定状态包含哪些信息。状态（state）是用于预测后续变化的环境描述，记为 s_t；机器人的位置、朝向和障碍物位置可以共同组成一个状态。**状态空间**（state space）$\mathcal{S}$ 收集任务中所有可能的状态，也就是这些信息在任务内允许出现的组合。动作 a_t 表示一次具体命令，**动作空间**（action space）$\mathcal{A}$ 则收集所有命令形式。命令可能只在某些状态下可执行，状态 s 下允许的命令组成 $\mathcal{A}(s) \subseteq \mathcal{A}$。

环境的描述与智能体实际收到的信息未必相同。观测（observation）是传感器或接口交给智能体的信息，记为 o_t：机器人的位置可以属于状态，相机拍到的局部图像则是观测。一张图像可能遮住了影响运动的障碍，因而不足以预测下一步。本章先假设智能体能够读取状态，以便集中讨论行

动与后果；不完整观测下如何使用历史 h_t，即截至当前取得的观测、动作和反馈，由第 4章处理。

我们用网格位置作为状态，把上述接口缩小到一个可以手算的任务。网格宽 4、高 3，坐标为 $x = 1, \dots, 4$、$y = 1, \dots, 3$；起点为 $(1, 1)$，终点为 $(4, 3)$，障碍 $(2, 2)$ 不可进入。到达终点的那一步得 1，其余非终止步得 -0.04。这些数值是教学假设，不是实验测量。方向命令可能因滑移而执行偏离，因此下面三条记录可以依次发生：

$$((1, 1), \text{右}, -0.04, (2, 1)),$$
$$((2, 1), \text{右}, -0.04, (2, 1)),$$
$$((2, 1), \text{右}, -0.04, (3, 1)).$$

第二条记录中，命令仍是向右，位置却没有改变。这可以由滑向障碍或边界造成，不能据此把动作改记为“停留”。经验同时保留命令和结果，才能区分选择规则与执行误差。

记录经验以后，学习器才有材料调整决策规则。图 1.2用实线表示每步执行，用虚线表示经验收集和参数更新：采集器可以每步记录，学习器却每积累一批经验才更新一次。部署时也可以固定参数，只保留执行闭环。因此，交互次数与梯度更新次数需要分别计算。

改变规则后，机器人可能进入此前很少经过的区域，新经验的分布也会改变。常见的固定数据监督学习分析把样本分布视为给定，强化学习还需处理行为改变数据来源的关系。监督学习方法也可以用于这样的闭环；这里区分的是问题设定，而不是把两类技术割裂开来[1]。

[1] R. S. Sutton, A. G. Barto, *Reinforcement Learning: An Introduction*, MIT Press, 2018, 2nd ed.

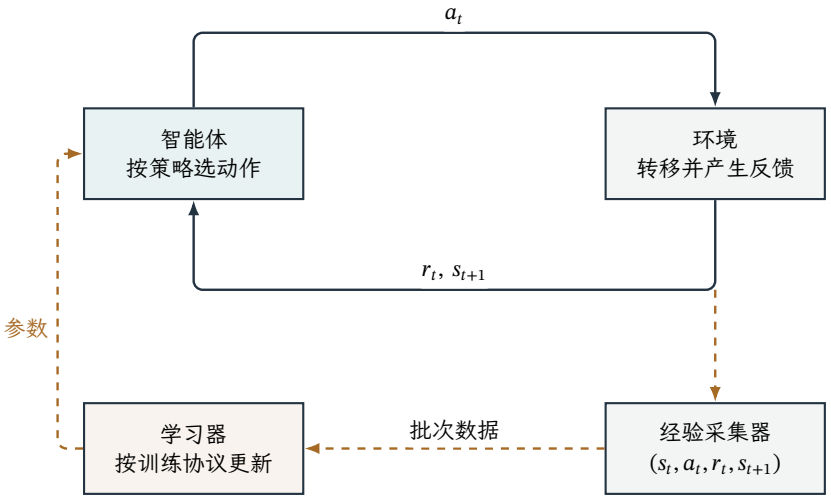


图 1.2　交互与学习的接口。实线是每步执行的动作和反馈，虚线是经验收集及按训练协议发生的参数更新。部署时可移除虚线部分而保留执行闭环。

1.1.2 马尔可夫决策过程

三条经验只告诉我们已经发生了什么，不能单凭它们计算在同一位置改选其他动作的后果。为此，需要一个环境模型，给出每个状态动作下可能的下一状态与奖励及其概率。若当前状态已经包含预测这些后果所需的信息，过去怎样到达这里就不再提供额外预测信息。这一条件称为马尔可夫性（Markov property）；它使我们能够从当前状态开始计算，而不必逐次重放历史。

把这样的转移规律与可选动作结合，得到**马尔可夫决策过程**（Markov decision process, MDP）。它描述智能体在哪些状态可以选哪些动作，以及每次选择如何产生后果；决策规则和评价目标仍须指定。在有限网格中，用 $p(s', r \mid s, a)$ 表示给定 s, a 后，下一状态为 s' 且奖励为 r 的联合概率，用 ρ_0 表示起始状态的分布。对同一状态动作下的所有奖励求和可得到下一状态的概率，按各结果的概率加权奖励则得到平均的一步评分。

定义 1.2　马尔可夫决策过程　马尔可夫决策过程由状态空间 $\mathcal{S}$、动作空间 $\mathcal{A}$、非空可行动作集合 $\mathcal{A}(s)$、联合转移奖励核 $p(s', r \mid s, a)$ 及初始分布 ρ_0 描述，并配以时域和评价目标。对有正概率的历史，马尔可夫性要求

$$\mathbb{P}(s_{t+1}, r_t \mid s_0, a_0, r_0, \dots, s_t, a_t) = p(s_{t+1}, r_t \mid s_t, a_t). \tag{1.1}$$

当状态与奖励取值有限或可数时，

$$\begin{aligned} P(s' \mid s, a) &= \sum_{r} p(s', r \mid s, a), \\ R(s, a) &= \sum_{s', r} p(s', r \mid s, a)\, r. \end{aligned} \tag{1.2}$$

P 是转移核，给出每种后继状态的概率；R 是给定状态动作后的条件期望奖励。连续状态或奖励时把相应求和改为积分。

将定义用于网格，我们就能补全尚未给出的概率。$\mathcal{S}$ 包含除障碍外的 11 个格子，起点固定，故 $\rho_0((1,1)) = 1$。动作名称是上、下、左、右；意图方向会越界或进入障碍的命令不在 $\mathcal{A}(s)$ 内。合法命令以 0.8 概率沿意图方向移动，以各 0.1 概率向两侧垂直方向滑移。滑移若撞墙或遇到障碍，则留在原位。

终点记为 $g = (4,3)$。到达后只保留虚拟动作“停留”，满足 $P(g \mid g, \text{停留}) = 1$，后续奖励为 0。这种吸收状态（absorbing state）一旦进入就不再离开。它允许我们把终止后的记录补成无限序列，同时不增加任务收益；后续讨论无限折扣目标时将沿用这一约定。

这项任务按实际后果计分，而不是按意图计分。从非终点状态出发，若 $s' = g$ 就返回 1，否则返回 -0.04。在 $(3,3)$ 选右时，有 0.8 概率到终点、0.1 因上方边界留在原位、0.1 滑到 $(3,2)$。要在执行前评价这一步的平均评分，需按这些概率加权，得到

$$R((3,3), \text{右}) = 0.8 \times 1 + 0.2 \times (-0.04) = 0.792.$$

其中 0.792 是重复执行时的期望，不是环境每次返回的奖励；一次实际反馈仍是 1 或 -0.04。一次样本不能确定期望，期望也不能唯一确定全部奖励分布。联合核 p 保留了后继状态与奖励的对应关系，而 P, R 分别汇总其中的状态概率和平均评分。

上述模型把位置当作充分状态，前提是位置相同、动作相同时，历史不会再改变后果分布。若网格新增一扇门，曾经取到钥匙会改变门的通行状态，那么同在门前的两个位置记录就可能对应不同转移。只记 (x, y) 不再充分。把开门状态 $b \in \{0, 1\}$ 加入 $s = (x, y, b)$，在其余机制固定时，增广状态才可能恢复这种充分性。式 (1.1)约束的是状态表示，并不是说世界没有过去；若 b 无法观测，扩充符号也不能让智能体自动取得这项信息。

MDP 还需要说明怎样把不同时刻的奖励合成一个目标。评价当前动作时，可以只累计接下来 H 步的结果；也可以让任务持续运行，用折扣因子（discount factor）γ 控制未来评分的权重，k 步后的奖励乘 γ^k。本章网格默认采用 $\gamma = 0.9$ 的无限时域折扣目标，并会明确标出独立的有限时域算例。表 1.1比较常见设定；平均奖励考察长期每步收益，随机最短路累计直到随机到达时刻的收益。这两类只作为边界入口，不能直接继承折扣问题的收敛结论。

设定	终止与时间	比较的目标	需另行检查的条件
有限时域	$t = 0, \dots, H-1$，$V_H = 0$ 表示末端无后续收益	H 步期望奖励总和，可另指定折扣	剩余时间影响决策；可并入状态
折扣无限时域	可持续运行；终止后补吸收状态	$\mathbb{E}\sum_{t\ge 0}\gamma^t r_t$	$0 \le \gamma < 1$；有界奖励使总和有限
平均奖励	通常持续运行，不因目标达成停止	$\lim_{n\to\infty} n^{-1}\mathbb{E}\sum_{t=0}^{n-1} r_t$	极限需存在；不可约（状态相互可达）或单链（只有一个长期停留且无法离开的互通区域）等条件关系到初始状态依赖
随机最短路	在随机时刻 τ 到达终点	$\mathbb{E}\sum_{t=0}^{\tau-1} r_t$，常用成本形式	需检查到达性、期望终止时间与不可终止策略的代价

表 1.1　同一状态动作接口可搭配不同时间目标。随机最短路中的“最短”可以指累计成本，不限于几何距离；取 $\gamma = 1$ 不能自动把折扣定理变成其余三类定理。

上述几类 MDP 的系统性处理可见 Puterman 的专著[2]。

[2] M. L. Puterman, *Markov Decision Processes: Discrete Stochastic Dynamic Programming*, John Wiley & Sons, 1994

1.2 动作

1.2.1 动作空间与可行动作

网格已经规定了方向命令，但真实任务不一定用有限个名称就能描述一次选择。受控机械系统可能需要一个连续的力向量 $\boldsymbol{u} \in \mathbb{R}^m$，其中 m 是控制分量数；推荐列表需要同时选择项目和次序；抓取命令则可能包含离散的抓取方式及连续的位置参数。比较这些动作形式，是为了确定决策规则需要输出什么，以及执行前怎样检查命令是否合法。

合法性首先由当前状态下的允许集合 $\mathcal{A}(s)$ 决定。若规则用概率分布选择命令，记为 $\pi(\cdot \mid s)$，就必须把全部概率放在这个集合内。这个记号只表示在状态 s 如何选动作，其完整类型将在策略一节定义。

定义 1.3　合法动作与策略支持　$\mathcal{A}$ 收集所有动作的可能形式，$\mathcal{A}(s) \subseteq \mathcal{A}$ 是状态 s 下允许执行的动作。对随机决策规则 $\pi(\cdot \mid s)$，合法性要求

$$\pi(\mathcal{A}(s) \mid s) = 1.$$

对离散动作，这等价于 $a \notin \mathcal{A}(s)$ 时 $\pi(a \mid s) = 0$，且合法动作的概率和为 1。确定性规则必须输出 $\mathcal{A}(s)$ 中的一个元素。

在图 1.3中，$(1,1)$ 允许上和右；$(3,2)$ 允许上、下和右，但左边是障碍。这里排除的是意图方向非法的命令，不是排除随机执行误差。另一种常见网格建模允许四个方向始终可选，把主动撞墙也规定为原地不动；那会增加可选行为，改变策略空间。本书贯穿网格采用前一种定义，只有随机滑移撞墙才留在原位。

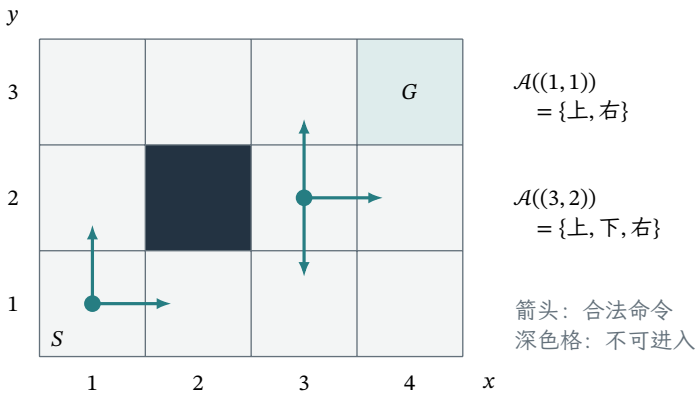


图 1.3　基准网格与两个位置的合法命令。实心方格是障碍，S 和 G 分别表示起点与终点；箭头表示可选择的意图方向，不表示随机滑移的全部后果。

表 1.2按一次命令的数学形式列出输出与约束。这里的分类不涉及命令持续多久：一个持续若干步的技能仍可用离散编号或连续参数选择，只是决策时间尺度不同。这一变化由下一小节处理。

命令能够执行，也不等于执行它满足安全要求。执行器只能提供有限大小的力，是动作接口的限制；某个力在硬件上可用，却可能因碰撞风险而被禁用，则是根据行为要求进一步限制动作。两种限制可以同时进入允许集合，但安全条件怎样建立、能保证什么，需由第 8章另行分析。

数学形式	策略输出对象	约束接口的例子
离散	一个动作编号或概率向量	方向掩码标出可用命令；仅对合法方向归一化
连续	向量 $\boldsymbol{u}$ 或其分布	力的上下界、联动约束
组合	子集、排列或多项联合选择	推荐列表长度、项目去重、容量限制
参数化	类型 c 及参数 $\boldsymbol{u}_c$	不同类型有各自维度和参数范围

表 1.2　动作的分类对象是一次命令的数学形式。执行器噪声属于转移机制，不会把离散命令自动变成连续动作。

1.2.2 动作后果与时间尺度

在起点提交同一个向右命令，改变执行机制就会改变后果。表 1.3固定 $s=(1,1)$ 和命令，只对照确定移动与基准滑移。两者即时奖励都为 -0.04，但确定移动总到 $(2,1)$，随机移动还可能进入左侧竖向通道或留在起点。只看这一步的评分，就看不到后续可达区域的变化。确定移动仅是本表的对照条件，其余网格计算仍保留滑移。

向右的后继状态	确定移动概率	基准概率	奖励
$(2,1)$	1	0.8	-0.04
$(1,2)$	0	0.1	-0.04
$(1,1)$	0	0.1	-0.04

表 1.3　同一向右命令在两种转移机制下的结果。基准的向下滑移越界，因此留在原位；零概率行仅用于对齐比较。

即使不改变机制，不同动作也可能具有相同即时奖励。在 $(3,2)$ 选择上或下，当步都不可能到达终点，所以期望奖励同为 -0.04。向上大概率到 $(3,3)$，下一步即可尝试进入目标；向下大概率回到 $(3,1)$，还需多次行动。一步评分无法表现这项差别。这里尚不声称某个动作必然最优，因为后续策略及随机转移也影响累计结果；它说明了为何需要一个跨越多步的评价对象。

多步后果也需要与记录时刻区分。图 1.4上行沿一条可发生的轨迹标出每次命令与反馈：执行 a_t 后得到 r_t，数步后到达终点的奖励则记录在到达

那一步。学习时可以用晚到的结果评价早先选择，这称为信用分配（credit assignment），也就是判断哪些早先行动应对后来的收益或失败承担作用。它改变评价方式，不改变奖励实际发生的顺序。

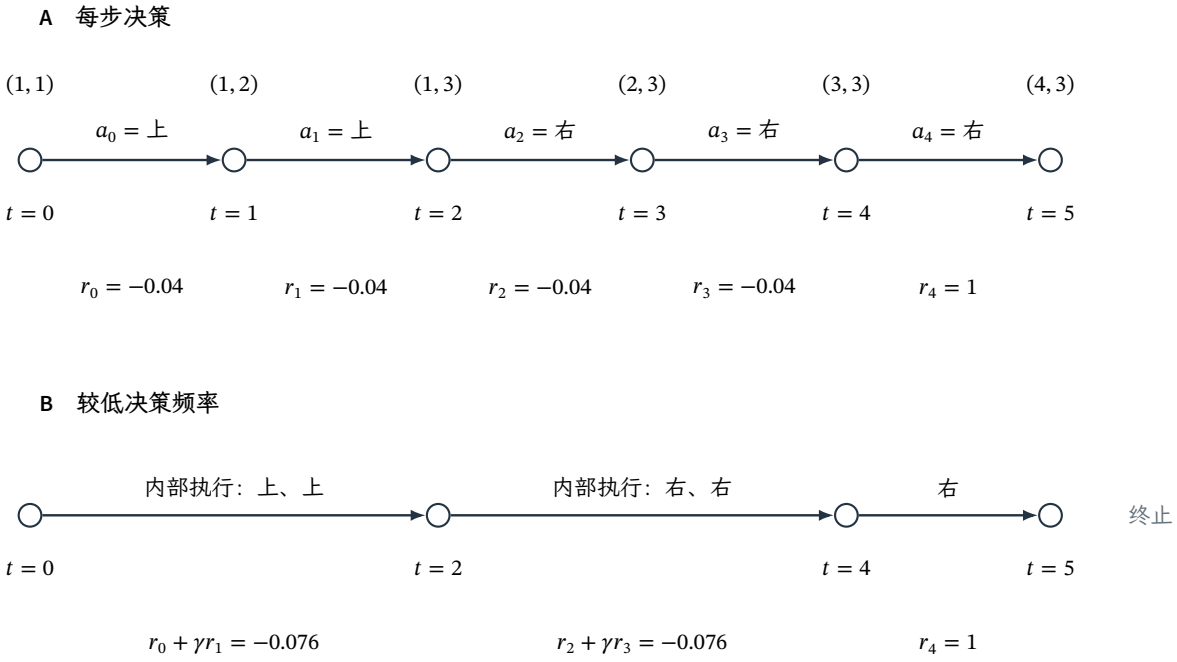


图 1.4 同一条五步到达轨迹的时间标记。上行每步决策，最后一个动作返回 $r_4 = 1$；下行只在 $t = 0, 2, 4$ 重新决策。下行跨两步的箭头表示持有或执行内部命令的区间，不能仍用上行的一步核和单步奖励表示。

图的下行改为每两步重新决策一次。这不只是少记录几个时刻：新接口的一次动作跨过两次原始转移，必须描述两步后的状态分布，并累计期间的评分。若命令持续 k 个原始步，在原始折扣 γ 下，区间内收益为 $\sum_{j=0}^{k-1} \gamma^j r_{t+j}$，区间外的回报再乘 γ^k。例如两个非终止步贡献 $-0.04 + 0.9(-0.04) = -0.076$，不能仍记为一个 -0.04。若持续时间随机，它也须作为动作后果的一部分。

连续时间控制进一步以物理时间而非固定步号描述运动，用微分动力学或跳变机制表示变化，奖励常是单位时间的收益率。离散化时，状态变化和区间收益必须一起调整，不能只改变决策频率。本章保留这些接口区别，不把其目标混入固定步长 MDP；跨步递归将在第 3章的时间抽象中展开。

1.3 策略

1.3.1 策略及其类型

若网格移动没有误差，从起点依次执行“上、上、右、右、右”就能沿上路到达终点。基准网格有滑移，一次偏离却可能使余下命令不再适合当前位置。因此，我们需要在每次取得状态后重新决定，而不只是预先写下一

个动作序列。**策略**（policy）就是根据当前可用信息选择行动的规则。此前的 $\pi(\cdot \mid s)$ 描述了它在状态 s 的动作分布；一次实际选出的 a_t 只是这条规则的一次结果。

规则可以始终相同，也可以随剩余时间改变。平稳策略（stationary policy）在同一状态使用相同的动作分布；非平稳策略（nonstationary policy）允许这份分布随时刻变化。若每次只指定一个动作，称为确定性策略（deterministic policy）；若按分布抽样，称为随机策略（stochastic policy）。这些区别需要分别记录，不能从是否抽样推断是否依赖时间。

定义 1.4　马尔可夫策略　一个马尔可夫策略序列为 $\pi = (\pi_0, \pi_1, \ldots)$，其中 $\pi_t(a \mid s)$ 是在时刻 t、状态 s 选择动作 a 的条件概率，并满足定义 1.3的支持条件。这里的马尔可夫策略在给定 t 后只使用当前状态，不再依赖此前历史。若规则不显式依赖 t，记为 $\pi(a \mid s)$，称为**平稳策略**；否则称为非平稳策略。若每个状态只输出一个合法动作 $f_t(s)$，则为确定性策略，对应退化分布 $\pi_t(a \mid s) = \mathbf{1}\{a = f_t(s)\}$。

更一般的策略可以依赖全部可用历史，写成 $\pi_t(a \mid h_t)$。本章完全可观测的主线使用上述马尔可夫策略，但不据此宣称在任何约束或信息条件下当前状态都足够。表 1.4展示抽样与时间依赖的四种组合：固定概率抽样可以是平稳的，每次确定地选择动作也可以随剩余时间改变。

	确定性	随机性
平稳	在起点总选上	在起点始终以 0.7 选上、0.3 选右
非平稳	根据剩余步数改选近路或远路	剩余时间多时以 0.7 选上，少时改为 0.2

表 1.4　两种互不等同的策略属性。表中的概率是教学规则，不是估计结果；各状态仍须满足各自的动作合法性。

有限时域为何可能需要时间？考虑一个从导航任务简化出的独立岔路例：取消滑移和步成本，近路只需一步即以 0.4 概率得到终点奖励 1，否则以奖励 0 终止；绕路需要两步，必得 1。在不折扣且到时终止的规则下，只剩一步时近路期望为 0.4、绕路为 0；还剩两步时两者为 0.4 和 1。同一岔路的选择随剩余时间改变。把剩余时间加入状态可以重新用平稳形式书写，但这相对于增广状态而言，并没有消除实际的时间依赖。

图 1.5在基准起点画出两份动作概率。一份以 1 的概率选择上，另一份以 0.7 选上、0.3 选右。即使采用第一份规则，下一状态仍以 0.8 概率为 $(1, 2)$、0.1 为 $(2, 1)$、0.1 留在起点。策略确定只能消除选动作时的随机性，不能消除转移随机性。有限折扣 MDP 何时存在最优确定性平稳策略，是第 2章要证明的结论，不是策略一词本身的含义。

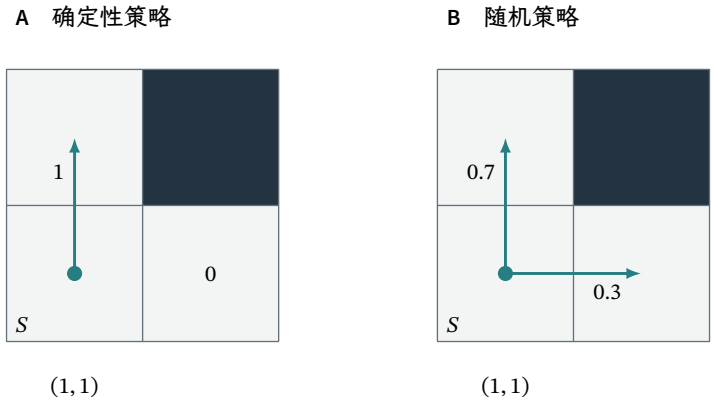


图 1.5 同一网格起点的两种动作分布。左边确定性策略仍有随机后继；右边额外引入动作选择的随机性。图只显示起点附近，未画出的位置沿用基准网格。

1.3.2 策略诱导的数据

起点选上与选右，会把机器人带向不同区域。要计算某份策略会产生哪些训练记录，我们先求一段记录出现的概率。把包含 H 步的有限轨迹记为 $\tau_H = (s_0, a_0, r_0, \dots, s_{H-1}, a_{H-1}, r_{H-1}, s_H)$。概率链式法则按发生顺序展开联合概率；马尔可夫性把每步环境条件缩减为当前状态动作，马尔可夫策略则给出该时刻的动作概率。因此，

$$\mathbb{P}_\pi(\tau_H) = \rho_0(s_0) \prod_{t=0}^{H-1} \pi_t(a_t \mid s_t)\, p(s_{t+1}, r_t \mid s_t, a_t). \tag{1.3}$$

初始位置来自 ρ_0，动作来自 π_t，反馈来自环境核 p。若只关心状态动作轨迹，对奖励求和后便得到含 $P(s_{t+1} \mid s_t, a_t)$ 的乘积；不能直接把 p 替换为“奖励恒等于 $R(s, a)$”。若策略依赖历史，链式分解依然成立，但动作项须改写为 $\pi_t(a_t \mid h_t)$。

沿用第 1.1.1节的三步记录，若在 $(1,1)$ 与 $(2,1)$ 都必选右，其概率为 $0.8 \times 0.2 \times 0.8 = 0.128$。中间的 0.2 是两种被阻挡的滑移概率之和。只把起点改为以 0.3 概率选右，保持后两次必选右，同一记录的概率就变为 0.0384。环境核没有改变，训练记录的分布却随策略改变了。

完整轨迹的种类很多，比较数据覆盖时往往只需知道各时刻在哪些状态采取哪些动作。逐时分布（time-marginal distribution）记录固定时刻的这些概率。若还要汇总无限多个时刻，就需约定它们各占多大权重。折扣目标让较早后果权重更大，我们相应地用 γ^t 加权逐时分布，并乘 $1-\gamma$ 使

权重之和为 1。得到的**折扣占用度量**（discounted occupancy measure）是一份状态动作分布，描述按这些时间权重抽样时会看到什么。

定义 1.5　逐时分布与折扣占用度量　逐时状态分布为 $q_t^\pi(s) = \mathbb{P}_\pi(s_t = s)$，状态动作分布为 $q_t^\pi(s,a) = q_t^\pi(s)\pi_t(a \mid s)$。对 $0 \le \gamma < 1$，归一化的折扣占用度量定义为

$$d^\pi(s,a) = (1-\gamma)\sum_{t=0}^{\infty}\gamma^t q_t^\pi(s,a), \qquad d^\pi(s) = \sum_a d^\pi(s,a). \tag{1.4}$$

我们可以把这种加权写成一次抽样：取独立于轨迹的时刻 T，满足 $\mathbb{P}(T=t) = (1-\gamma)\gamma^t$，则 $\mathbb{P}_\pi(s_T = s, a_T = a) = d^\pi(s,a)$。它不是一条轨迹中“至少到访一次”的概率，反复到访与晚到访都会影响加权结果。要核对 d^π 确实归一化，可利用各项非负交换求和次序，再用每一时刻的概率质量为 1：

$$\sum_{s,a} d^\pi(s,a) = (1-\gamma)\sum_{t=0}^{\infty}\gamma^t \underbrace{\sum_{s,a} q_t^\pi(s,a)}_{1} = 1.$$

终止后必须保留吸收状态及其虚拟动作，以上质量才仍然为 1；若把终止后的时刻全部删除，得到的是非终止占用，其总质量一般小于 1。吸收状态的占用高也不表示在那里继续取得奖励，因为其奖励为零。

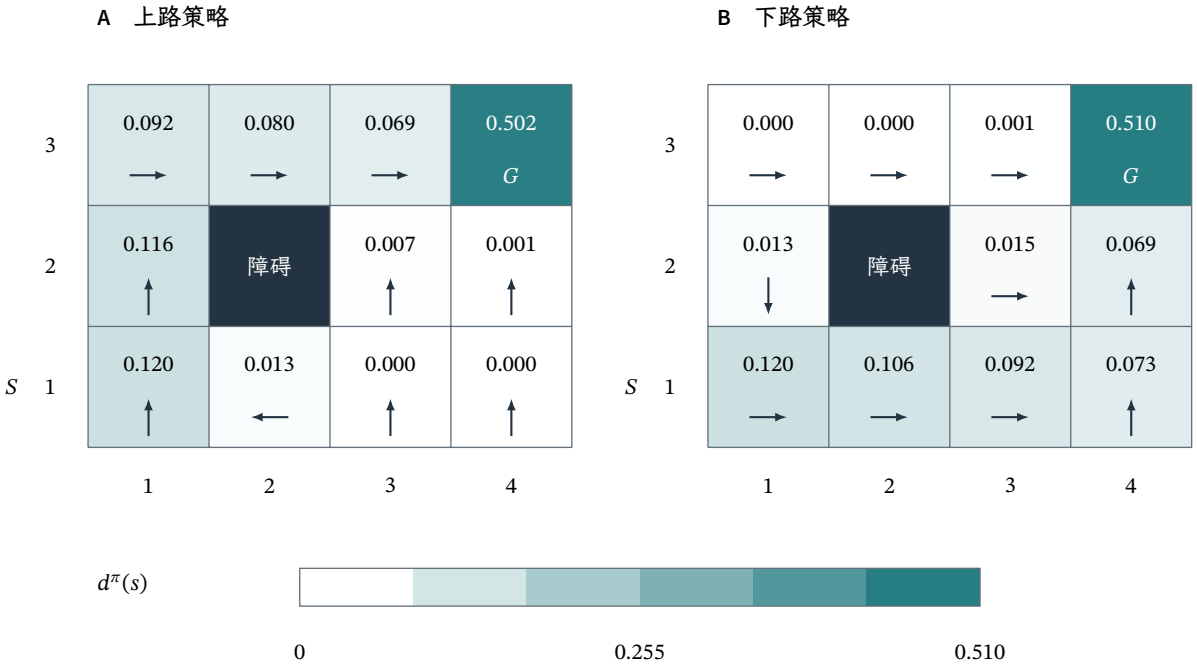
平稳策略还满足 $d^\pi(s,a) = d^\pi(s)\pi(a \mid s)$，因为每个时刻在 s 的动作分布相同。非平稳策略的占用仍由式 (1.4)定义，但不能把随时间变化的 π_t 直接提出求和号。这一区别在后续利用占用度量恢复平稳策略时会用到。

图 1.6把加权分布用于比较两份完整的确定性策略。箭头给出每个非终点格的唯一意图方向，深浅及数字表示 $d^\pi(s)$，不是价值。计算时先从 $q_0 = \rho_0$ 出发，对当前状态概率、动作概率和后继概率逐层加权，将分布传播到下一步：

$$q_{t+1}^\pi(s') = \sum_s q_t^\pi(s)\sum_a \pi(a \mid s)P(s' \mid s,a)$$

再按式 (1.4)累加各时刻分布。保留 400 个时刻时，总质量尾差为 $0.9^{400} < 5\times10^{-19}$。两幅图采用同一色标：上路策略在左侧通道的占用较大，下路策略则更多到访底边。因此，即使时间采样权重和采样预算相同，两份策略也会给不同区域提供不同数量的证据。

这种数据来源差异在“用旧规则的经验评价新规则”时尤其重要。实际收集数据的规则称为**行为策略**（behavior policy），记为 μ，它决定日志怎样产生；希望评价或改进的规则称为**目标策略**（target policy），记为 π，它决定我们想知道谁的后果。两者相同称为同策略（on-policy）问题，不同



终点含吸收质量；数值保留三位小数，颜色使用同一尺度。

图 1.6 基准随机网格中两份策略的归一化折扣状态占用，ρ_0 集中于起点，$\gamma = 0.9$。箭头是确定性策略，滑移仍为 0.8/0.1/0.1；数字四舍五入至三位小数，障碍不是零概率的可用状态。

称为离策略（off-policy）问题。这一划分比较的是两份规则，与能否新增数据的在线、离线划分不同。

用 μ 的记录推断 π，需要检查记录是否包含目标规则所需的状态动作后果。若行为分布从不给某个必要动作正概率，已有样本的重新加权不能生成该动作的后果。这是覆盖（coverage）问题：数据来源必须为待推断的行为提供足够支持，而不只是拥有很多条记录。

在 $(2, 1)$，合法动作是左、右，两侧滑移都只会停留。若 μ 在此永远选左，日志就没有从该格主动向右的样本，尽管 π 可能需要向右。另一种情况是 μ 允许进入左侧通道，但某份有限日志恰好没到过那里。前者是行为分布本身不支持必要动作，后者可能只是有限抽样遗漏，二者不能混为同一结论。

跨位置推断可以借助函数逼近（function approximation），也就是让不同位置的预测共享参数；其可靠性仍需结构假设和数据证据。网络能输出一个未尝试动作的预测，不等于该预测已被验证。占用的流守恒及由占用恢复策略将在第 2章展开，离策略覆盖的后果则由第 4章进一步分析。

1.4 奖励

1.4.1 奖励与累计回报

策略决定怎样行动，奖励规则则决定怎样给行动后果计分。基准网格每个非终止步付出 0.04，到达终点得到 1，同时表达了到达目标与避免拖延的偏好。远离终点时，大多数动作的即时奖励同为 -0.04；只比较这个数值，就无法区分它们将机器人带向哪里。因此，我们需要把后续奖励一起纳入评价。**回报**（return）就是按指定时间规则累计的奖励，它将一串反馈合成一个数值。

沿用前面的折扣因子，折扣回报以 γ^k 加权 k 步后的奖励。选择 $0 \le \gamma < 1$，意味着越远的收益对当前判断权重越小。对随机策略和随机转移，一份策略可能产生许多条轨迹；本章按期望回报比较它们，即比较同一初始分布下长期评分的平均值，而不是要求每条轨迹都最好。

定义 1.6　回报与策略目标　奖励样本 r_t 是一次交互返回的数值，$R(s,a) = \mathbb{E}[r_t \mid s_t = s, a_t = a]$ 是环境的条件期望奖励。回报是从某时刻起按指定时间目标累计的奖励。折扣情形为

$$G_t = \sum_{k=0}^{\infty} \gamma^k r_{t+k}, \qquad 0 \le \gamma < 1. \tag{1.5}$$

相对于给定初始分布 ρ_0，策略目标为 $J(\pi) = \mathbb{E}_\pi[G_0]$。它是未归一化的期望折扣回报，不是单条轨迹的实现值。

若任务只计入时刻 t 至 $H-1$ 的奖励，且没有额外终端收益，累计范围就缩为剩余的 $H-t$ 步：

$$G_{t,H} = \sum_{k=0}^{H-t-1} \gamma^k r_{t+k}.$$

有限和允许 $\gamma = 1$，这时每一步权重相同。若任务持续运行，关心的是长期每步取得多少收益，则可以把前 n 步总收益除以 n，再考察 n 增大后的极限。从状态 s 启动、遵从策略 π 的期望时间平均为

$$g^\pi(s) = \lim_{n\to\infty} \frac{1}{n} \mathbb{E}_\pi\left[\sum_{t=0}^{n-1} r_t \,\middle|\, s_0 = s\right],$$

这里须假设极限存在。该式先对随机轨迹取期望，再取时间极限；它与沿某条轨迹计算平均后得到的样本路径结论不同，本章不默认二者相等。表 1.5比较三种累计口径，尤其要观察终止后的零奖励：它不改变奖励总和，却会被持续计入时间平均的分母。

累计方式	权重与归一化	终止后怎样处理
有限回报	$H-t$ 项；$\gamma=1$ 时为总和而非步均值	H 之后不计收益；另有终端收益须显式给出
折扣回报	权重 γ^k；本书 J 不乘 $1-\gamma$	吸收状态的零奖励不改变回报
期望时间平均	总和除以 n 后取极限	若终止后永远零奖励且总收益可积，平均值为零

表 1.5　回报的累计口径。对一个只产生有限总收益的到达任务使用无限时间平均，会失去区分路径的能力；这不是折扣回报的另一种写法。

示例 1.7　同一网格上的两条到达轨迹　路径甲共五步，依次经过

$$(1,1)\to(1,2)\to(1,3)\to(2,3)\to(3,3)\to(4,3).$$

路径乙先从 $(1,1)$ 到 $(2,1)$ 再回起点，然后沿甲前进，共七步。这是两段可发生的实际轨迹，不是两种策略的全部可能结果。甲的奖励为 $(-0.04,-0.04,-0.04,-0.04,1)$，乙比甲多两个前置的 -0.04。我们固定这两串奖励，分别比较是否折扣对累计结果的影响。

不折扣时，两者回报分别为 $1-4(0.04)=0.84$ 和 $1-6(0.04)=0.76$。取 $\gamma=0.9$ 时，每个奖励再乘它发生时刻对应的权重：

$$\begin{aligned} G_0^{\text{甲}} &= -0.04(1+0.9+0.9^2+0.9^3)+0.9^4 \\ &= 0.51854, \\ G_0^{\text{乙}} &= -0.04\sum_{k=0}^{5}0.9^k+0.9^6 = 0.3440174. \end{aligned}$$

绕路的回报较小，不只是因为多付了两步成本；折扣还降低了晚到的终点奖励权重。两条已发生轨迹的比较说明了累计规则，却不能直接比较两份随机策略的期望。

即时评分与累计评分甚至可以给出相反排序。另设一个确定性教学岔路：近路一步得 0.4 后终止，远路前两步得 0、第三步得 1，没有其他奖励。取 $\gamma=0.9$，近路当前得分较高，累计回报却只有 0.4，小于远路的 0.81。该例取消了滑移并改变了奖励，不是原网格的计算；下一小节将保持这两条路径不变，考察折扣因子改变时排序如何变化。

有限轨迹可以直接相加，无限回报则需确认总和存在。计算时也不可能逐项累加到无穷，我们还需要控制只保留前 H 步造成的误差。若每步奖励的绝对值不超过统一上界 $R_{\max}$，就可以用奖励界乘几何权重之和，同时回答存在性和截断误差两个问题。

定理 1.8　有界折扣回报与截断误差　设对所有 t 几乎处处有 $|r_t| \le R_{\max} < \infty$，且 $0 \le \gamma < 1$。则折扣级数绝对收敛，并对任意 t 及整数 $H \ge 1$ 满足

$$|G_t| \le \frac{R_{\max}}{1-\gamma}, \qquad \left| G_t - \sum_{k=0}^{H-1} \gamma^k r_{t+k} \right| \le \frac{\gamma^H R_{\max}}{1-\gamma}. \tag{1.6}$$

对这些量取任意条件期望，同样的绝对误差界仍成立。

证明　先把每个奖励的大小用 $R_{\max}$ 控制。对任意有限整数 n，三角不等式与奖励界给出

$$\sum_{k=0}^{n} \left|\gamma^k r_{t+k}\right| \le R_{\max} \sum_{k=0}^{n} \gamma^k = R_{\max} \frac{1-\gamma^{n+1}}{1-\gamma} \le \frac{R_{\max}}{1-\gamma}.$$

绝对值部分和单调且有上界，因而极限有限，原级数绝对收敛。再对整个和使用三角不等式，就得到第一式。截断只删去 $k \ge H$ 的项；对这段尾项使用相同的奖励界，得到

$$\left| \sum_{k=H}^{\infty} \gamma^k r_{t+k} \right| \le R_{\max} \sum_{k=H}^{\infty} \gamma^k = \frac{\gamma^H R_{\max}}{1-\gamma}.$$

若 $\gamma = 0$，回报只保留 r_t，任意 $H \ge 1$ 的尾项均为零，结论仍成立。对任意给定信息 $\mathcal{F}$，由 $|\mathbb{E}[X \mid \mathcal{F}]| \le \mathbb{E}[|X| \mid \mathcal{F}]$，对逐轨迹的确定上界取条件期望就得到所述期望界。 ■

基准网格可取 $R_{\max} = 1$。只保留前 50 步时，通用尾界为 $10(0.9)^{50} \approx 0.05154$；这是所有满足奖励界的轨迹都适用的保守控制，不是网格的实际误差。若预先允许的误差为 $\varepsilon > 0$，可以反过来选择截断长度。对于 $0 < \gamma < 1$ 和 $R_{\max} > 0$，解 $\gamma^H R_{\max}/(1-\gamma) \le \varepsilon$ 可得 $H \ge \log(\varepsilon(1-\gamma)/R_{\max})/\log\gamma$，再取满足条件的正整数；分母为负，解不等式时必须改变方向。若 $R_{\max} = 0$，所有奖励及截断误差均为零。这些结论依赖折扣，不能用于 $\gamma = 1$ 的无限任务。

1.4.2　时间目标与奖励边界

在前一小节的确定性岔路中，$\gamma = 0.9$ 时远路回报更高。若更重视眼前收益，这个排序还会保持吗？我们固定近路 (0.4) 和远路 $(0, 0, 1)$ 两串奖励，只改变折扣因子。该例仍没有滑移和步成本。按奖励发生的时刻加权，两条路径的回报为

$$G^{\text{近}}(\gamma) = 0.4, \qquad G^{\text{远}}(\gamma) = \gamma^2.$$

两条路径回报相等时，$0.4 = \gamma^2$，故交点为 $\gamma_* = \sqrt{0.4} \approx 0.63246$。在这两条候选路径中，$\gamma < \gamma_*$ 时近路回报较高，$\gamma > \gamma_*$ 时远路较高，交点处相等。图 1.7绘出的是解析函数，不是学习曲线，也没有实验误差带。把 γ 从 0.5 换成 0.9 后选择翻转，是目标改变的结果，不能据此判断求解算法失效。

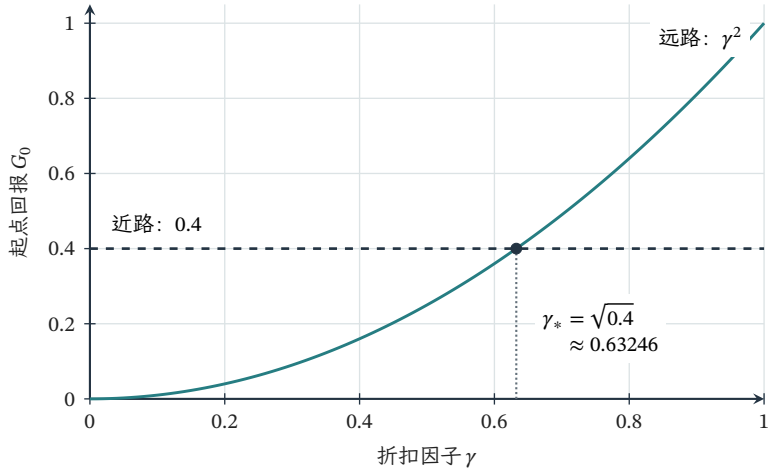


图 1.7　独立确定性岔路算例的折扣偏好。横轴为 γ，纵轴为起点回报；近路奖励序列为 (0.4)，远路为 $(0, 0, 1)$，无其他奖励。交点由解析等式求出。

累计范围也可能因为时间上限而改变，但要先判断上限来自任务还是采集器。若任务规定“十步内到达才得分”，第十步之后的奖励不属于目标，剩余步数应进入决策信息，终端价值按规则设为零。若任务持续运行，只是采集器最多记录十步，s_{10} 之后的回报并未消失。我们可以用未来价值估计补齐未记录部分，这称为自举（bootstrapping），即用已有预测代替尚未观测的后果；也可以不补齐，但需承担式 (1.6)给出的截断误差。自举不能应用于本来就不计入目标的未来。区分真正终止与采样截断，要依据任务规则，而不能只看一个含混的结束标记。

即使累计方式明确，奖励也可能鼓励我们不希望看到的行为。另设一个确定性导航任务，保留 $\gamma = 0.9$、原步成本和终点奖励，但增加一条两步循环。起点可以沿五步路径到达终点，也可以不断循环；到达路径不经过奖励路标，循环每步却都因经过路标多得 0.2。循环每步净得 0.16，无限循环的回报为 $0.16/(1 - 0.9) = 1.6$，超过五步到达的 0.51854。这个算例取消了滑移并新增了循环，不是基准网格的精确解。选择循环可能完全符合给定奖励，却违背到达目标的意图。辅助奖励要在促进学习的同时保持最优策略不变，需要额外条件，第 5章再讨论。

奖励符合收益意图后，按期望比较仍有边界。设一个策略的回报必为 1，另一个以各一半概率得 3 或 -1；二者期望相同，后者却有一半概率出现负结果。平均数不能恢复失败概率、极端损失或不可违反的条件。第 8章将分别讨论怎样评价回报分布、允许环境发生哪些扰动，以及行为必须满足哪些安全约束；把惩罚系数调大，不能自动给出这些保证。

1.5 价值

1.5.1 状态价值、动作价值与优势

前面的轨迹算例在奖励串给定后计算回报，决策时却尚不知道会发生哪条轨迹。我们需要在动作发生前比较可能的长期结果。**价值函数**（value function）用条件期望回答这个问题：固定环境、目标和后续策略，平均会得到多少回报。状态价值（state value）$V^\pi(s)$ 让当前动作也按策略 π 选择；动作价值（action value）$Q^\pi(s,a)$ 先固定当前动作 a，此后才遵从 π。两者的差称为**优势**（advantage），衡量这一个动作相对当前策略在该状态的平均行为多得或少得多少回报。

定义 1.9　状态价值、动作价值与优势　对固定平稳策略 π，折扣状态价值与动作价值分别为

$$\begin{aligned} V^\pi(s) &= \mathbb{E}_\pi[G_t \mid s_t = s], \\ Q^\pi(s,a) &= \mathbb{E}_\pi[G_t \mid s_t = s, a_t = a]. \end{aligned} \tag{1.7}$$

条件事件有正概率时，以上采用通常的条件期望。对任意状态 s，第一式按从 s 启动并遵从 π 定义；对任意合法动作 a，第二式按从 s 启动、强制执行 a、随后遵从 π 定义。因此，状态不必在原初始分布下可达，动作也不必满足 $\pi(a \mid s) > 0$。优势定义为 $A^\pi(s,a) = Q^\pi(s,a) - V^\pi(s)$。有限时域或非平稳策略需要保留 $V_t^\pi, Q_t^\pi, A_t^\pi$ 的时间下标。

要从各动作的价值恢复策略在该状态的价值，需要把当前动作选择也平均进去。候选动作来自 $\mathcal{A}(s)$，权重由固定策略 $\pi(a \mid s)$ 给出，而不是在这里挑选最大值。由全期望公式，

$$V^\pi(s) = \sum_{a \in \mathcal{A}(s)} \pi(a \mid s) Q^\pi(s,a). \tag{1.8}$$

优势用 $V^\pi(s)$ 作共同基线。将其定义代入这个动作平均，再利用合法动作的概率和为 1，得到

$$\sum_a \pi(a \mid s) A^\pi(s,a) = \sum_a \pi(a \mid s) Q^\pi(s,a) - V^\pi(s) = 0.$$

正优势表示相对于当前策略在该状态的平均行为更好，并不表示相对于最优行为已经足够好，也不表示每次执行都会成功。

示例 1.10 随机网格中的两步价值 为了手算一次行动前的比较，保留基准网格全部转移与奖励，只将目标改为两步有限时域 $H=2$，$\gamma=0.9$，$V_2=0$。从 $c=(3,3)$ 开始，时刻 1 在 c 选右，在 $(3,2)$ 选上，在 $(2,3)$ 选右；其他状态任选合法动作，不影响以下计算。时刻 1 只剩一步，因此各处价值就是该步的期望奖励：

$$V_1^\pi(c)=0.792,\quad V_1^\pi((3,2))=-0.04,$$
$$V_1^\pi(g)=0,\qquad V_1^\pi((2,3))=-0.04.$$

当前选右，以 0.8 到终点，以 0.1 留在 c，以 0.1 到 $(3,2)$。第一步期望奖励为 0.792；第二步的期望回报按后继概率平均，再折扣一次，故

$$Q_0^\pi(c,\text{右})=0.792+0.9[0.1(0.792)+0.1(-0.04)]=0.85968.$$

当前选左或下时，按各自后继分布同样相加：

$$\begin{aligned}Q_0^\pi(c,\text{左})&=-0.04+0.9[0.8(-0.04)+0.1(0.792)+0.1(-0.04)]\\&=-0.00112,\\Q_0^\pi(c,\text{下})&=0.1(1)+0.9(-0.04)+0.9[0.8(-0.04)+0.1(-0.04)]\\&=0.03160.\end{aligned}$$

向下也可能因侧滑进入终点，所以其即时期望是 0.064，不能误写成 -0.04。若 π_0 以 0.5 选右、0.25 选左、0.25 选下，则

$$V_0^\pi(c)=0.5(0.85968)+0.25(-0.00112)+0.25(0.03160)=0.43746.$$

三个动作的优势依次为 $0.42222,-0.43858,-0.40586$，按这些概率加权恰好为零。

图 1.8将这组数值放回格点，中心是当前策略的平均价值，箭头旁则是固定首动作的价值及其相对基线。只把 π_0 改为必选右，后续规则不变，三个 Q_0 也不变，但 V_0 变为 0.85968。再把时刻 1 在 c 的选择改为左，就有 $V_1(c)=-0.04$，当前向右的价值也变为 $0.792+0.9[0.1(-0.04)+0.1(-0.04)]=0.7848$。这个对照分别改变了当前动作分布和后续策略，说明价值取决于环境、时间目标与策略，不是格子固有的属性。

同一个 $J(\pi)$ 还可以从数据分布来计算。逐时分布 $q_t^\pi(s,a)$ 告诉我们时刻 t 遇到每种状态动作的概率，$R(s,a)$ 给出对应的平均奖励；两者相乘再求

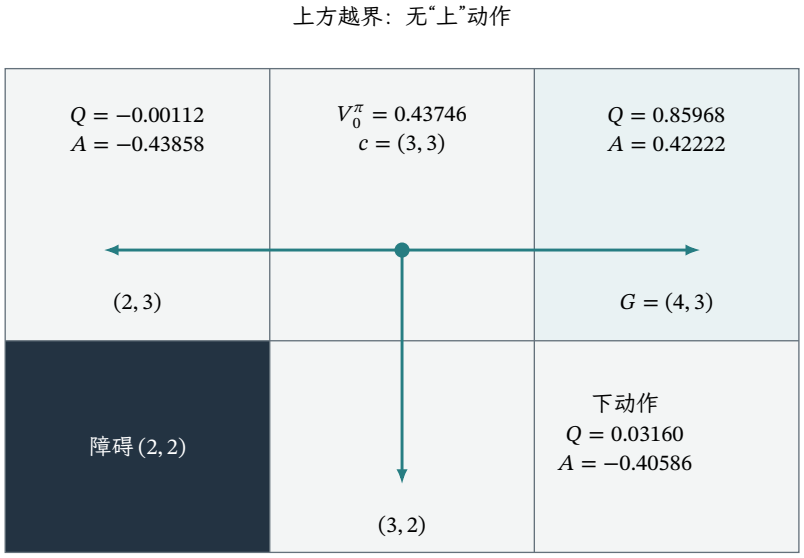


图 1.8　两步算例在 $c = (3, 3)$ 的价值分解。中心为 V_0^π，三个合法意图方向标出 Q_0^π 与 A_0^π；上方越界，因而没有上动作。全部数值对应示例 1.10，不是无限时域最优价值。

和，就是该时刻的期望评分。对时刻加折扣权重，便恢复总目标。有界奖励使级数绝对可和，允许交换期望与求和，得到

$$\begin{aligned} J(\pi) &= \mathbb{E}_{s_0 \sim \rho_0} V^\pi(s_0) = \sum_{t \geq 0} \gamma^t \sum_{s,a} q_t^\pi(s, a) R(s, a) \\ &= \frac{1}{1-\gamma} \sum_{s,a} d^\pi(s, a) R(s, a). \end{aligned} \tag{1.9}$$

最后一行用 d^π 汇总时间权重，但它比原来的折扣和多乘了 $1-\gamma$，所以恢复 J 时必须除以这一系数。这把“策略去哪里、做什么”与“那些行为得到多少奖励”联系起来；后续占用分布的梯度和误差界须沿用同一归一化约定。

1.5.2　回报的递归关系

两步算例先计算最后一步，再把它带回当前一步。能否用同样的分解处理更长的未来，而不逐条枚举轨迹？折扣回报的第一项是 r_t，剩余各项都含一个共同的 γ。对绝对收敛级数提取这个因子，得到

$$G_t = r_t + \gamma G_{t+1}. \tag{1.10}$$

对有限时域也有同样关系，只是末端为 $G_{H,H}=0$。这种分解没有近似；难点是把右边尚未发生的随机量转换成可计算的条件期望。

当前固定 $s_t=s,a_t=a$ 后，下一步奖励和状态仍然随机。先对可能的 r_t,s_{t+1} 分情况，再评价从后继状态继续行动的回报：马尔可夫性使环境未来只依赖 s_{t+1}，平稳策略使未来选择也只依赖后续状态。因此，$\mathbb{E}_\pi[G_{t+1}\mid s_t,a_t,r_t,s_{t+1}]=V^\pi(s_{t+1})$。由条件期望的塔式法则，

$$Q^\pi(s,a)=\sum_{s',r}p(s',r\mid s,a)[r+\gamma V^\pi(s')]. \tag{1.11}$$

该式把当前动作的价值变成一步反馈与后继状态价值的平均。用式 (1.8)平均当前动作，可得到 V^π 的递推；用同一式替换后继 V^π，可得到 Q^π 的递推。两式称为Bellman **期望关系**（Bellman expectation equations），它们都在评价固定策略，平均权重来自策略与环境，而不是对动作求最优：

$$V^\pi(s)=\sum_a\pi(a\mid s)\left[R(s,a)+\gamma\sum_{s'}P(s'\mid s,a)V^\pi(s')\right], \tag{1.12}$$

$$Q^\pi(s,a)=R(s,a)+\gamma\sum_{s'}P(s'\mid s,a)\sum_{a'}\pi(a'\mid s')Q^\pi(s',a'). \tag{1.13}$$

从联合核改写成 P,R 时，分别平均 r_t 和后继价值，只使用了期望的线性性，不要求二者独立。网格奖励恰好由后继状态决定，仍可使用这两式。递推现在给出了计算关系，但还需核对它计算的确实是原来定义的回报期望。有限时域可以从零终端值逐步往前验证；无限时域则需用尾项界控制有限截断与完整回报的差。

定理 1.11　回报期望与递推一致　对有限状态动作 MDP，给定马尔可夫策略序列 π，若有限时域各步奖励可积、终端价值为零，按 $V_H^\pi=0$ 及

$$V_t^\pi(s)=\sum_a\pi_t(a\mid s)\sum_{s',r}p_t(s',r\mid s,a)[r+\gamma V_{t+1}^\pi(s')] \tag{1.14}$$

反向计算，得到的量等于 $\mathbb{E}_\pi[G_{t,H}\mid s_t=s]$。这里允许环境核 p_t 随时刻变化；时间齐次时 $p_t=p$。对时间齐次模型、固定平稳策略、有界奖励与 $0\le\gamma<1$，无限折扣回报的条件期望满足式 (1.12)和式 (1.13)。

证明　与价值定义相同，零概率条件事件处采用从指定状态启动的含义。有限时域在 $t=H$ 无剩余奖励，两边都为零。假设时刻 $t+1$

的递推值已经等于剩余回报的条件期望。将 $G_{t,H}=r_t+\gamma G_{t+1,H}$ 代入，再按动作、奖励和后继状态逐层取条件期望，得到

$$\begin{aligned}&\mathbb{E}_\pi[G_{t,H}\mid s_t=s]\\&\quad=\sum_a \pi_t(a\mid s)\sum_{s',r} p_t(s',r\mid s,a)\\&\qquad\times\left[r+\gamma\mathbb{E}_\pi[G_{t+1,H}\mid s_{t+1}=s']\right].\end{aligned}$$

内层条件期望只需 s_{t+1}，是因为模型在给定时刻满足马尔可夫性，未来采用指定的策略序列。代入归纳假设就得到式 (1.14)。由 $t=H-1$ 逐次归纳到 $t=0$，有限结论成立。固定当前动作而不平均 π_t，同一论证给出有限时域的 Q_t^π 关系。

对无限折扣情形，令 $V^{\pi,[n]}(s)$ 为从 s 开始只累加前 n 步的回报期望，方括号表示截断长度而非更新迭代。由已经证明的有限结论，

$$V^{\pi,[n]}(s)=\sum_a \pi(a\mid s)\left[R(s,a)+\gamma\sum_{s'}P(s'\mid s,a)V^{\pi,[n-1]}(s')\right].$$

定理 1.8给出对所有 s 一致的界 $|V^{\pi,[n]}(s)-V^\pi(s)|\le\gamma^n R_{\max}/(1-\gamma)$，因而左边收敛到 $V^\pi(s)$。右边加权平均的差至多为 $\gamma\cdot\gamma^{n-1}R_{\max}/(1-\gamma)$，也趋于零，故极限满足式 (1.12)。对固定首动作的截断回报重复同样步骤，得到式 (1.11)；再用动作平均关系替换其中的 V^π，即得到式 (1.13)。 ■

证明从回报定义出发，先验证有限递推，再用尾项界过渡到无限回报，因此没有用递推本身假定价值存在。但“价值满足这些式子”还不能反过来说明只有这一个函数满足它们，也不能说明反复计算右侧会收敛。固定点唯一性与计算误差由第 2章补足。

图 1.9将式中的两层平均分开：先按策略选择动作，再按环境生成后继。若不再按当前策略平均，而是在合法动作中选择期望累计回报最大的一个，问题就从评价这份策略转为改进行为。最大值的候选集合是 $\mathcal{A}(s)$，比较指标是动作的期望回报；这一新的求解问题也由规划章展开。

1.6 强化学习的研究内容

网格的行为规则和长期目标已经明确，仍有不同的研究任务：我们可能只想评价上路策略，也可能想找一份新策略，还可能需要决定到哪里收集经验。定位这些任务，要分别说明求什么、能取得什么数据、用什么证据判断结果。下面三个小节按这三个方面展开，而不是把算法分成互斥类别；一个算法可以同时估计价值、改进策略和学习环境模型。

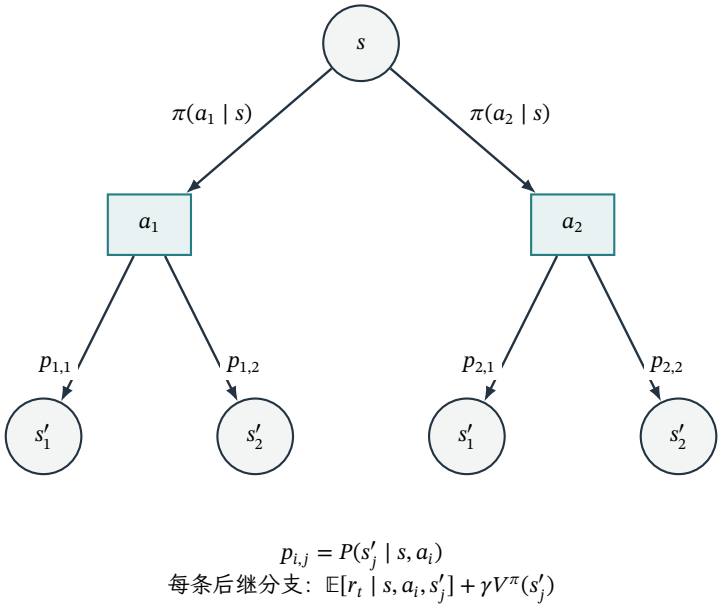


图 1.9 Bellman 期望备份的两层随机性。圆节点表示状态，方节点表示动作；第一层以 $\pi(a \mid s)$ 平均，第二层以 $P(s' \mid s, a)$ 平均后继价值。给定状态动作的即时奖励平均为 $R(s, a)$；若按后继分支同时计入奖励，需保留奖励与后继状态的条件关系。

1.6.1 核心研究问题

给定图 1.6中的上路策略，我们可以先问它从起点出发的期望折扣回报是多少。**策略评价**（policy evaluation）保持规则不变，求出这份规则的长期后果。若问题改为能否找到回报更高的合法策略，就进入**控制**（control），即选择或改进决策规则。转移未知时，回答这两个问题还需要数据。**探索**（exploration）决定去哪些状态尝试哪些动作，以取得区分行为后果所需的信息。一次探索绕行可能降低当次收益，却帮助以后选择，因而不能只按当次即时得分判断它的作用。

这些任务的输出不同：评价可以给出价值估计 $\widehat{V}$，控制给出策略 $\widehat{\pi}$，探索改变经验的采集规则。还可以估计转移与奖励，得到 $\widehat{P}, \widehat{R}$，用于预测行动后果并规划，但预测误差也会进入求解过程。基于模型（model-based）方法显式使用这类环境预测模型求解行为；无模型（model-free）方法不经过这一步，而直接估计价值或调整策略。这里的“模型”指环境后果模型，不是泛指神经网络；价值网络本身不使方法成为基于模型的方法。

图 1.10把这些输出放回经验闭环。真实反馈与对应预测的差可以提供学习信号，价值可以指导策略更新，新策略又改变下一批经验。图中的通路可以组合，不要求每个算法经过全部通路。信用分配研究晚到反馈怎样关联早先行动；表示学习（representation learning）寻找适合预测和控制的

状态特征；收敛分析检查更新序列是否趋于目标及其条件。它们研究的是多条通路共有的困难，不是与价值方法互斥的算法家族。

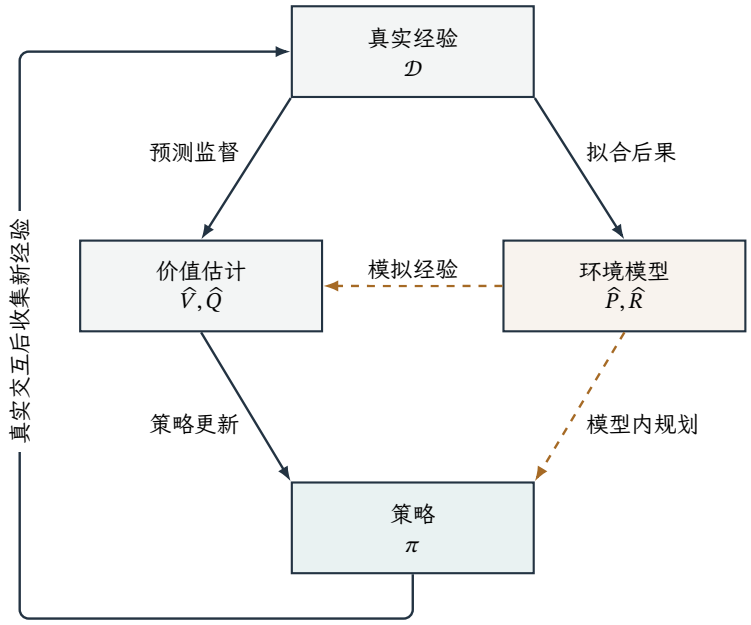


图 1.10 研究对象之间可能的信息流。实线为真实经验、预测监督及价值驱动的策略更新；虚线为使用学习模型生成的规划信息或模拟经验。模型预测与真实环境始终是不同对象。

输出不同，验证方式也不同。表 1.6中，价值估计对应估计误差，策略则对应相对允许策略类中最优规则的回报差，称为策略损失（policy performance loss）。若价值误差只在常去的状态很小，关键岔路上的动作排序仍可能出错，就不能据此保证策略损失小。持续学习还要计算相对指定基准的累计收益损失，通常称为遗憾（regret）；它计入学习期间的代价，与最终检查点的回报不同。完整更新过程及统计条件由第 3章展开。

问题	主要输出	与问题相符的证据
评价	$\hat{V},\hat{Q},\hat{J}$	指定分布下误差、置信范围或一致性
控制	一份策略 $\hat{\pi}$	$J(\pi^*)-J(\hat{\pi})$，其中 π^* 为允许策略类中的最优策略
探索	采样规则与交互历史	达到误差要求的交互数；学习期间相对固定基准的累计收益损失
模型学习	$\hat{P},\hat{R}$ 或潜在动态	覆盖区域内预测误差，以及误差对真实策略回报的影响

表 1.6 研究对象及证据类型。持续交互的累计收益损失常称遗憾，其基准、时间目标和是否按回合计算必须另外定义，不能混用不同口径。

1.6.2 问题边界与变体

要评价 $(3,3)$ 向右的后果，真实机器人通常须先走到那里，仿真器却可能允许直接指定这个位置，固定日志则只能提供已经记录的样本。三者可以对应同一份 MDP，但允许取得数据的方式不同。能从指定合法 (s,a) 反复随机采样后果的接口称为**生成模型**（generative model）：它是一项查询能力，不特指神经网络生成模型。查询返回随机样本，也不同于直接读出全部转移概率并计算精确期望。表 1.7固定网格任务，对照重置、查询点与新增经验三项权限。

访问协议	能否重置	能否指定查询点	能否增加经验	网格中的实际含义
在线轨迹	只按环境规定，常在回合开始重置	不能默认；通常先走到该格	可以，需付真实交互代价	到达 $(3,3)$ 以后才能测试向右
生成模型	可把查询起点设为给定状态	可以指定合法 (s,a)	可以取得模型样本	无须从起点走来就可测试 $(3,3)$
固定日志	无交互接口	不能，只能筛选已有记录	不可以	没记录的岔路不能主动补采
有限批次交互	按每批采集协议	不能由“批次”一词推出	只在规定的轮次和预算内	收集一批后更新，再申请下一批

表 1.7　固定任务下的数据访问差异。仿真样本与真实交互应分别计费；在线并不保证任意重置，批次交互也不自动提供生成模型能力。

访问权限之外，任务本身的条件也可以改变。先固定状态、动作与奖励规则：模型已知时求解是规划，模型未知时要从经验学习后果，分别对应第 2、3章。若相机无法辨认位置，改变的是决策时的观测条件；若训练只能用旧日志，改变的是学习时的经验获取条件，第 4章分别处理二者。奖励样本可见但期望未知，仍属于标准学习；若连可信的标量评分也无法取得，才需要从示范、偏好或检查行为结果的验证器构造目标，进入第 5章。

目标格、摩擦或观测界面跨任务变化，要求复用经验并适应新任务，对应第 6章。多个机器人共同挤占通道时，其他参与者的策略影响转移及收益，对应第 7章。若要求碰撞概率受控、动力学扰动下仍有效或永不进入禁止区域，则还需第 8章的行为要求与保证。这五章从共同的规划与学习基础出发，分别考察信息、反馈、任务、参与者和行为要求，不是必须依次执行的算法步骤。现实任务可以同时具有多项限制；分别固定其他条件，有助于辨认每种方法补足了什么能力。

一个具体反例可以检验两类“信息不足”的区别。日志完整记录了每个位置，却从未包含 $(2,1)$ 处向右的后果，这是数据覆盖不足；机器人有充足交互机会，但摄像头把两个走廊拍得完全相同，这是当前观测无法分辨状态。前者不能仅靠增加记忆解决，后者可能需要历史线索或主动探测，而非重复使用同一条无区分力的观测。更大的网络可以表达更复杂的假设，却不能无条件创造缺失信息。同一个方法能回答哪些问题，取决于它实际获得的信息与访问权限。

1.6.3 评价与研究证据

在同一网格中，方案甲可以每收集一步经验就多做模型内计算，方案乙则立即继续行动。甲可能用更少真实数据达到某个回报，却花更多训练时间。这说明“算法更好”必须落实到具体指标：最终回报、达到目标所需的交互数、训练时间或失败概率。若环境采样便宜而规划昂贵，用计算换数据未必节省墙钟时间，即从开始到结束实际经过的时间。比较时须同时固定任务目标、预算和计数单位。

评价最终行为时，应冻结训练后的策略，在固定测试初始分布和时间目标下，用独立测试回合估计 $\mathbb{E}[G_0]$。训练中最好的一条轨迹不能代替这个平均。评价样本效率（sample efficiency）时，可以预先设定回报阈值，再统计达到阈值所需的真实转移数；未达到的运行也须保留并说明处理方式，不能从平均中删除。

表 1.8列出各指标必须固定的量。尤其要区分同一策略的测试波动与训练过程的波动：多个测试回合考察一份训练结果，独立训练种子则还改变初始化、采样和更新过程。不能用前者代替后者来说明跨种子稳定性。

指标	必须固定的量	分母、预算或评价分布
最终回报	冻结的检查点、动作采样规则、奖励尺度	测试初始分布上的每回合回报，报告回合数
真实样本效率	性能阈值及何时检查；失败运行的处理	真实环境转移数，不把模型内样本混入
训练计算	硬件、并行度、模型规模、调参范围	总墙钟时间及设备时，包含规划和数据处理
决策计算	相同硬件与任务负载	每次动作的平均及尾部延迟，单位毫秒
跨种子稳定性	独立训练种子、相同预算	种子级成绩分布及不确定区间
任务外泛化	训练任务与未见测试任务的划分	每个测试任务；另列适应交互及更新预算
约束违反	禁止事件及观察时段	每回合违反概率或每步频率，二者分别报告

表 1.8 评价指标的定义边界。同一个数字只有在分母、目标与评价分布相同的条件下才能比较；约束违反不能用高平均回报掩盖。

将小节开头的比较具体化，可以让方案甲每收集一步真实经验做 100 次模型内备份，即按价值递推更新预测，方案乙做 1 次直接价值更新。两者都只允许 10^4 步真实交互，在相同真实步数处测量测试回报，同时累计训练耗时、模型查询数和决策延迟。再另设相同墙钟预算，比较该预算结束时的测试回报。100 与 10^4 只是教学协议，不是测得的性能。第一种比较若支持甲，说明甲在指定真实数据预算下回报更高；只有时间预算比较也支持，才能声称它在该设置下用时更省。

复核还需要环境版本、动作重复频率、结束规则、奖励预处理、训练与测试种子、超参数搜索次数以及检查点选择规则。调参使用的验证任务与最终测试任务应分开，否则任务外泛化混入了选择偏差。多任务平均分也应保留各任务成绩，避免少数高分任务遮住失败任务。

这些协议也限定了证据能支持什么结论。定理给出假设内的普遍关系，却不保证机器人或推荐系统满足假设。受控消融（controlled ablation）固

定其他条件、移除某个部件，考察该部件在当前设置中的影响，不能直接证明它是所有任务成功的原因。跨基准结果增加测试任务，却仍受共同实现、数据和选择协议限制。三类证据互相补充，回答的并非同一个问题。第 3章进一步讨论统计报告，第 8章处理有限证据能支持多强的部署保证。

1.7 强化学习的研究历史

前面用一个网格把行为、回报与价值连在一起，历史上这些认识却来自不同问题。行为研究问结果怎样改变以后的选择，控制与运筹学问已知动态时怎样优化多阶段行动，预测学习问怎样从连续经验修正长期估计。现代强化学习逐步将它们接入共同接口，再扩展表示规模和问题条件。以下沿思想来源、框架形成、规模扩展与边界变化梳理代表工作；年代用于定位研究，不用于推断因果影响或方法优劣。

1.7.1 强化学习的思想源流

一种行为得到某种结果后，以后还会不会再被选择？试错学习从这个现象出发，关注后果怎样改变行为倾向。Thorndike 在早期行为研究及 1911 年的专著中讨论效果律（law of effect），将情境、行为与后果联系起来。这为“根据结果调整行为”提供了问题意识，却没有给出本章的状态空间、折扣目标和 Bellman 方程。现代概念可以帮助我们说明两者的联系，不能据此把现代 MDP 定义当作早期研究者的原话[3]。

控制论与运筹学面对的是另一项长期决策问题：系统动态和目标已知时，怎样选择一系列控制使总收益最大或总成本最小？Bellman 的动态规划（dynamic programming）把长问题分成后继子问题，用子问题的价值计算当前选择，避免直接穷举全部行动序列。价值递归与最优性原理支撑这种分解，不要求先从未知环境学习转移。本章推导的是固定策略的 Bellman 期望关系；对动作进行优化的部分将在规划章展开[4]。

预测学习还有一条重要线索：终局结果很晚才出现，能否用相邻时刻的预测差来修正当前预测？Samuel 在跳棋程序中研究了从经验改善局面评价的方法，后续时序差分文献将这类思想与连续预测误差联系起来。这里的任务接口包含棋局规则与搜索，不应把它等同于一个不知道任何规则的现代在线基准[5]。

Sutton 在 1988 年的工作中系统讨论**时序差分**（temporal difference, TD）预测，即不必等到最终结果，而用“一步反馈加下一次预测”修正当前预测。这一思路把价值递归变成了可由经验近似的学习关系。它与试错控制的联系需要再加入行为改进环节，预测本身不会自动改变动作[6]。

图 1.11将三条线索并排呈现。行为改进提供“根据结果改变选择”的认识，动态规划提供“长期结果可以递归分解”的认识，TD 提供“相邻预测

[3] E. L. Thorndike, *Animal Intelligence: Experimental Studies*, The Macmillan Company, 1911

[4] R. Bellman, *Dynamic Programming*, Princeton University Press, 1957

[5] A. L. Samuel, *Some Studies in Machine Learning Using the Game of Checkers* In IBM Journal of Research and Development, 1959, vol. 3, no. 3, pp. 210–229

[6] R. S. Sutton, *Learning to Predict by the Methods of Temporal Differences* In Machine Learning, 1988, vol. 3, pp. 9–44

之间的误差可以驱动学习”的认识。三者能够在现代闭环中组合，却并非每条线索先完成以后下一条才开始；图中的平行时间带正是为了区分这些认识。

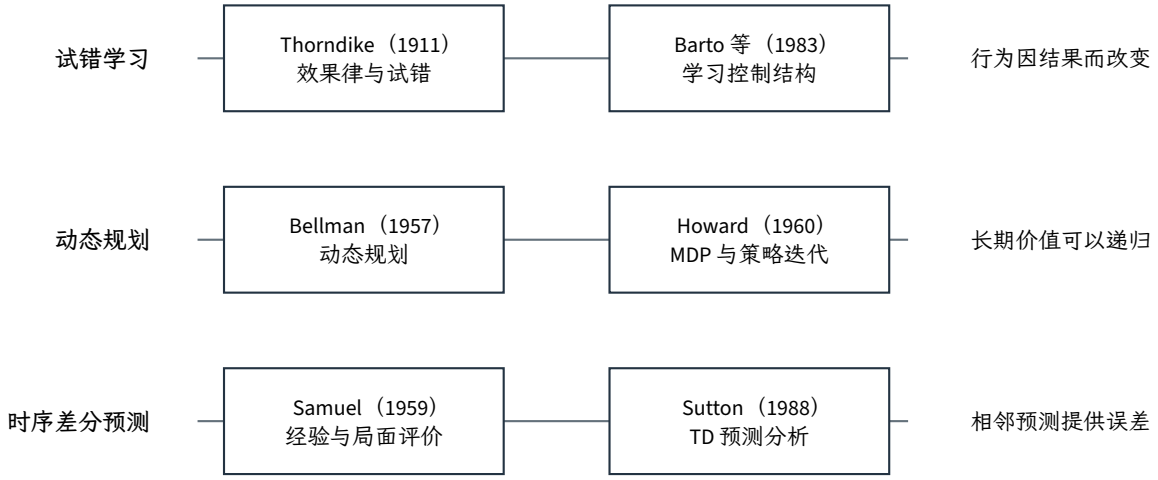


图 1.11 三条思想线索的代表节点。各带从左到右按年代阅读，节点间距不按年份等比例缩放；平行线表示研究线索，不表示一种思想取代另一种。节点作者与年份对应附近正文的原始来源。

1.7.2 现代强化学习框架的形成

在网格中，已知 p 可以计算价值，只有一步经验则需要估计价值。MDP 将动作、转移、奖励与价值放进共同模型，使这两种条件能够明确区分。Howard 在 1960 年的专著中系统发展了 MDP 的动态规划与策略迭代（policy iteration），即交替计算当前策略的价值、据此改进策略。它提供已知模型下的求解基准，并不声称一个新动作的奖励样本就能揭示所有后果[7]。

模型未知时，可以运行固定策略至回合结束，将实际回报作为价值样本并反复平均。这称为蒙特卡罗评价（Monte Carlo evaluation），用采样回报估计长期期望。TD 不必等到完整回报，而用一步奖励加后继预测构造目标；这减少等待，却也使目标依赖当前预测。为表示目标与当前预测的差，令 $\widehat{V}^{(k)}$ 为第 k 次更新时的价值估计，对经验 (s_t, a_t, r_t, s_{t+1}) 定义误差 δ_t：

$$\delta_t = r_t + \gamma \widehat{V}^{(k)}(s_{t+1}) - \widehat{V}^{(k)}(s_t).$$

式中 $r_t + \gamma \widehat{V}^{(k)}(s_{t+1})$ 是这次经验给出的目标，减去 $\widehat{V}^{(k)}(s_t)$ 才得到预测误差。蒙特卡罗改用完整样本回报作为目标。二者估计同一个长期对象，但等待时间、抽样波动和预测误差进入目标的方式不同。

预测还需影响后续选择，才能从评价进入控制。**行动者—评论家**（actor–critic）用两个部件完成这一联系：行动者给出动作分布，评论家估计行为后果，并向行动者提供更新信号。Barto、Sutton 与 Anderson 在 1983 年的学习控制工作中研究了这种配合结构[8]。其控制实验用失败反馈改进平衡

[7] R. A. Howard, *Dynamic Programming and Markov Processes*, The Technology Press of the Massachusetts Institute of Technology, 1960

[8] A. G. Barto, R. S. Sutton, C. W. Anderson, *Neuronlike Adaptive Elements That Can Solve Difficult Learning Control Problems* In IEEE Transactions on Systems, Man, and Cybernetics, 1983, vol. SMC-13, no. 5, pp. 834–846

行为，将行为评价与行为调整连起来；学习能否稳定，仍需分析两个部件的相互影响，不能由各有一个网络推断。

另一条控制路线直接学习最优动作价值。Q-learning（Q 学习）用实际一步后继构造目标，并在该后继状态的合法动作中取价值估计的最大值，以表达后续选择更高回报动作的目标。Watkins 的 1989 年博士论文提出该方法，Watkins 与 Dayan 在 1992 年的论文中给出详细收敛证明。证明依赖表格表示、重复访问和步长条件；更新含最大值并不表示一次采样就已找到最优策略[9]。

[9] C. J. C. H. Watkins, P. Dayan, *Q-Learning* In Machine Learning, 1992, vol. 8, pp. 279–292

表 1.9按更新对象与数据条件对照这些方法。Q-learning 与固定策略 TD 的区别已经可以从目标看出：前者使用 $r_t + \gamma \max_{a'} \widehat{Q}^{(k)}(s_{t+1}, a')$，其中 a' 只遍历 s_{t+1} 的合法动作；后者评价固定策略的后续行为，不在目标中寻找另一份规则。这里的公式用于辨认求解对象，完整算法、收敛条件和实践偏差由第 3章展开。

文献或方法	问题设定与更新对象	数据或模型来源	历史贡献的限定表述
Bellman（1957）、Howard（1960）	给定模型，价值与策略	可计算转移期望和奖励	建立递归求解与策略改进基准
蒙特卡罗评价	固定策略，估计回报期望	完整轨迹的实际回报	用随机样本平均替代枚举全部轨迹
Barto 等（1983）	学习控制，评价部件与行动部件	与受控系统交互的反馈	联结预测误差与行为调整
Sutton（1988）	连续预测，更新价值估计	一步经验与已有预测	系统分析时序差分预测
Watkins、Dayan（1992）	表格控制，估计最优 Q	重复访问状态动作的经验	证明限定条件下 Q-learning 收敛

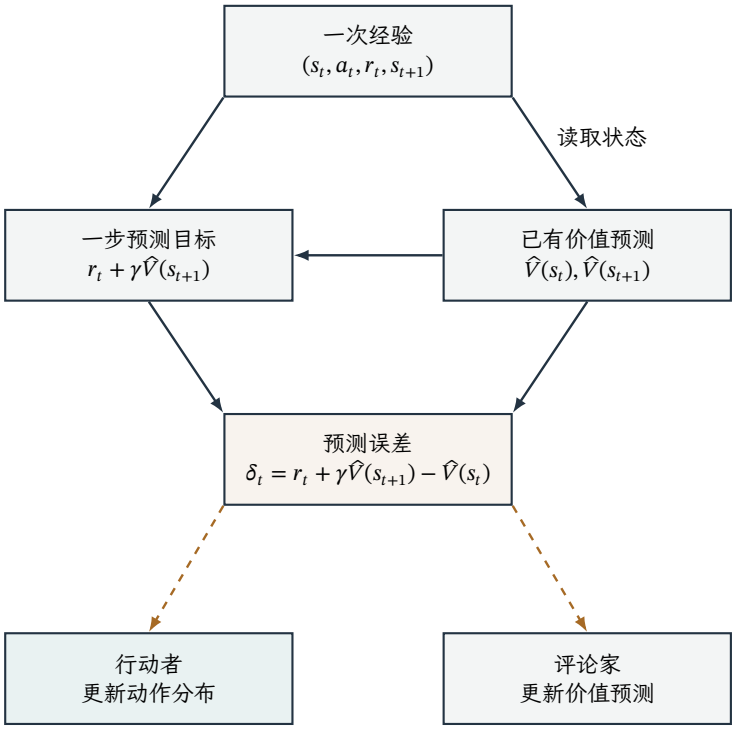
表 1.9　统一框架的形成与具体方法的贡献。蒙特卡罗行是教材中的方法类别，不用一个任意年份代替其更广泛的模拟历史；其余行对应正文给出的原始文献。

图 1.12收拢这个闭环：一条经验可以改变预测，也可以经由预测误差改变以后采取同类行动的概率。执行与更新仍是不同过程，某些方法按回合更新，另一些按步或批次更新。现代框架统一的是问题接口与长期目标，不是要求所有方法拥有同一个训练时钟。

1.7.3 函数逼近与规模扩展

网格只有 11 个状态，可以为每个状态保存一个价值。若状态包含连续位置、速度和关节角，就不能为每种取值单独开表项；即使每个维度离散成 m 格，d 个维度也产生 m^d 个组合。此前用于解释跨位置推断的函数逼近，在这里用一组共享参数计算不同状态的价值或动作分布，代替逐个保存表项。减少表项的代价是不同状态的预测开始相互影响。

线性价值逼近用特征的加权和计算价值，写为 $\hat{V}_\theta(s) = \boldsymbol{\phi}(s)^\top \boldsymbol{\theta}$；特征向量 $\boldsymbol{\phi}(s)$ 与待估参数 $\boldsymbol{\theta}$ 维数相同。神经网络则可同时学习非线性表示与输出。表示受限后，原来的价值可能无法精确写出，近似动态规划（approx-



更新后的策略决定未来行动；误差不是环境新发的奖励。

图 1.12 从一次经验到预测与行动的更新。箭头表示信息依赖；误差并非新的环境奖励，更新后的策略只影响未来的数据收集。

imate dynamic programming）研究如何仍用这种表示计算价值并改进行为。Bertsekas 与 Tsitsiklis 的神经动态规划专著系统连接了动态规划、仿真与函数逼近的计算问题[10]。

[10] D. P. Bertsekas, J. N. Tsitsiklis, *Neuro-Dynamic Programming*, Athena Scientific, 1996

我们用两个状态观察这种相互影响。设教学特征为 $\boldsymbol{\phi}(u) = (1,0)^\top$、$\boldsymbol{\phi}(v) = (1,1)^\top$，初始 $\boldsymbol{\theta} = (0,0)^\top$，只在 u 得到目标 1。用平方损失 $\frac{1}{2}(\hat{V}_{\boldsymbol{\theta}}(u) - 1)^2$ 衡量预测与目标的差，其初始梯度为 $(-1,0)^\top$。步长 0.1 的一次梯度下降得到 $\boldsymbol{\theta} = (0.1,0)^\top$，两处预测都从 0 变为 0.1。表格更新则只会改变 u 的数值，图 1.13对照了这两种结果。若 v 的正确目标也接近 1，共享可能有益；若 v 应接近 -1，同一次更新就在 v 增大了误差。

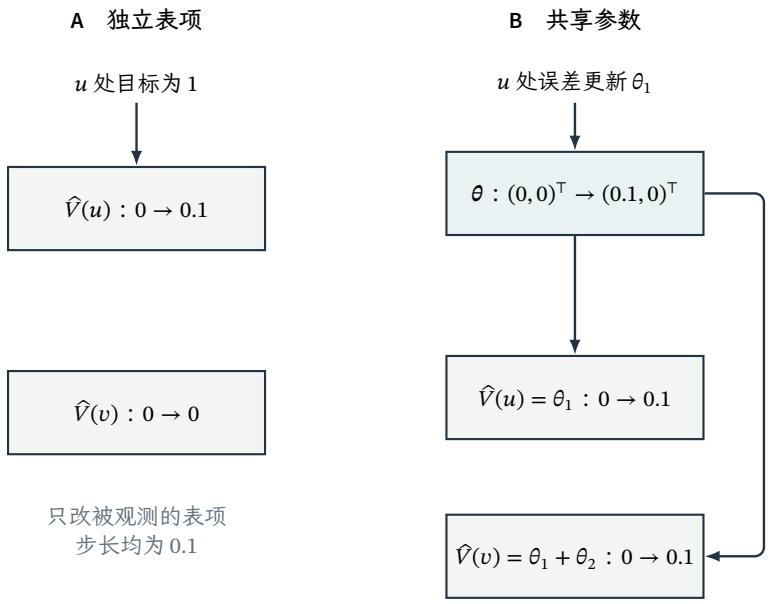


图 1.13 表格与共享参数的局部更新。仅在 u 观察到目标 1、步长为 0.1；表格中 v 不变，线性逼近中两个状态都依赖 θ_1，因而预测同时变化。数值来自正文的两特征教学例。

共享参数也可以直接表示策略,而不只是价值。策略梯度(policy gradient)按期望回报对策略参数的变化率调整行为。Williams 在 1992 年研究的 REINFORCE 用采样回报估计这项梯度，后续方法进一步结合价值估计以控制抽样方差。它使连续或随机行为的改进能够写成参数优化，但仍需说明数据来自哪份策略、梯度波动多大，以及目标回报怎样定义。策略网络可微并不要求环境动态可微，也不能据此推断环境可微[11]。

[11] R. J. Williams, *Simple Statistical Gradient-Following Algorithms for Connectionist Reinforcement Learning* In Machine Learning, 1992, vol. 8, pp. 229–256

这种共享并不总能与原来的更新规则兼容。函数逼近、自举和离策略采样组合时存在发散反例：参数更新会改变后继预测，自举又将改变后的预测放入下一轮目标；行为数据的权重还可能与目标策略的状态分布不同。存在反例不等于所有逼近都发散，却足以说明表格收敛证明不能直接用于任意网络。第 3章将区分有保证的线性条件、反例与深度方法的稳定化设

计。共享缓解了存储及逐状态取样的压力，同时引入状态间干扰，这是规模扩展新增的困难。

1.7.4 深度强化学习的兴起

当决策输入变为游戏画面时，固定特征设计本身就需要处理高维信息。深度 Q 网络（deep Q-network, DQN）结合卷积表示与动作价值学习，从堆叠画面估计各离散动作的长期价值。画面堆叠提供短时变化信息，不保证任意任务中的状态充分性。经验回放（experience replay）保存交互记录并重新抽样，复用数据、降低连续样本的相关性；目标网络（target network）在一段更新内固定目标预测的参数，减缓自举目标变化。表示与目标稳定化共同参与学习，不只是将价值表替换成大网络。2015 年论文在 49 个 Atari 游戏上报告结果，证据对应原文的画面预处理、动作重复和交互预算，不能扩大到任意真实环境[12]。

连续力矩还有另一项障碍：不能逐一枚举所有动作并比较价值。深度确定性策略梯度（deep deterministic policy gradient, DDPG）用确定性行动者直接输出连续动作，评论家估计动作价值，再用价值对动作的梯度指导行动者更新。它保留经验回放和目标网络，并在交互时加入探索噪声。原工作比较模拟物理控制中的低维状态与部分像素输入条件；模拟结果提供这些条件下的证据，不构成真实机器人可靠控制的无条件保证[13]。

围棋也有大量后继，但规则已知，可以直接生成候选落子的结果。AlphaGo 的 2016 年系统用策略网络指导搜索、价值网络评估局面，并结合蒙特卡罗树搜索（Monte Carlo tree search），即用模拟对局结果逐步分配搜索预算[14]。训练既使用人类棋谱的监督信号，也使用自我对弈（self-play），让系统通过与自身对局产生经验。搜索不需要从图像学习棋子怎样移动，而是查询已知规则。DQN、DDPG 和 AlphaGo 都使用深度网络，数据与模型访问条件却不能视为相同。

表 1.10按组件职责而非年份归组。DQN 的成功不证明回放适用于每种数据条件，AlphaGo 的成功也不证明一个可查询规则的游戏与不可安全重置的机器人同样容易。神经网络、稳定化设计、搜索与规模计算共同扩大了能够求解的任务范围，但如何在分布变化和失败代价下建立可靠性证据仍是独立问题。

1.7.5 研究范围的拓展

研究内容一节已经区分观测、数据、反馈与任务等条件，扩大网络并不能消除这些限制。仓储机器人可能看不见完整状态，不能安全试错，或者到了一个与训练时不同的仓库。这些问题也并非都在深度强化学习之后出现。部分可观测决策已有长期规划研究，Kaelbling、Littman 与 Cassandra

[12] V. Mnih, K. Kavukcuoglu, D. Silver, A. A. Rusu, J. Veness, M. G. Bellemare, A. Graves, M. Riedmiller, A. K. Fidjeland, G. Ostrovski, S. Petersen, C. Beattie, A. Sadik, I. Antonoglou, H. King, D. Kumaran, D. Wierstra, S. Legg, D. Hassabis, *Human-Level Control through Deep Reinforcement Learning* In Nature, 2015, vol. 518, pp. 529–533

[13] T. P. Lillicrap, J. J. Hunt, A. Pritzel, N. Heess, T. Erez, Y. Tassa, D. Silver, D. Wierstra, *Continuous Control with Deep Reinforcement Learning* In International Conference on Learning Representations, 2016

[14] D. Silver, A. Huang, C. J. Maddison, A. Guez, L. Sifre, G. van den Driessche, J. Schrittwieser, I. Antonoglou, V. Panneershelvam, M. Lanctot, S. Dieleman, D. Grewe, J. Nham, N. Kalchbrenner, I. Sutskever, T. Lillicrap, M. Leach, K. Kavukcuoglu, T. Graepel, D. Hassabis, *Mastering the Game of Go with Deep Neural Networks and Tree Search* In Nature, 2016, vol. 529, pp. 484–489

组件	DQN	DDPG	AlphaGo（2016）
表示与输出	卷积网络输出离散动作 Q	行动者输出连续动作，评论家输出 Q	棋盘表示上的策略概率和局面价值
回放与目标	回放复用交互，目标网络缓慢刷新	回放与平滑目标更新	不能把其棋谱、自我对弈数据误记成 DQN 回放流程
行为改进	由动作价值选择动作	通过评论家优化行动者	监督策略训练、自我对弈改进及搜索
搜索与模型	不用显式转移模型做前瞻	不依赖已知动力学规划	依赖已知围棋规则进行树搜索
计算与证据	大量模拟交互及网络训练	模拟连续控制、训练与执行成本分开	网络训练与比赛时搜索都消耗资源

表 1.10　代表性深度系统的计算需求与组件作用。表格不把特定系统中没有采用的组件判为无用，也不把不同任务分数放在一个性能排序中。

在 1998 年的工作系统讨论了利用历史信息规划和行动的框架。神经记忆可以改变历史的表示方式，仍需判断哪些隐状态与观测相符[15]。

固定数据研究关注另一个限制：日志很多，不等于可以继续试验。旧行为没有尝试的后果不能直接从日志识别，离线评价与保守改进因此需显式处理覆盖边界。所谓保守改进，是在证据不足处限制对新行为的信任，而不是默认它更安全。

示范与人类反馈改变的则是目标来源。专家可以展示动作，也可以给出偏好，即指出两个行为结果中更愿接受哪一个，学习者需把这些信号转为可优化目标。Christiano 等 2017 年的工作用人类对短轨迹片段的偏好训练奖励预测，再与策略学习形成反馈环。标量奖励由另一个学习过程取得，也因此受反馈覆盖和奖励失配影响[16]。

多个决策者共同影响后果时，环境也会随其他参与者的策略变化。Shapley 在 1953 年研究随机博弈（stochastic game），将状态转移与多个参与者的共同决策联系起来；单智能体固定环境中的最优策略不能直接推广到共同学习的参与者。增加行为要求则可采用约束 MDP（constrained MDP），除收益目标外另设成本限制，表达期望资源或风险预算，Altman 的专著系统处理了这些问题。独立约束指定了必须满足的预算，与在奖励中选一个很大的负数不同[17,18]。

表 1.11将范围扩展与后文章节连接。多任务与迁移不仅问能否在多种训练任务上拟合成功，还问改变目标或动力学以后可以复用什么、必须重新识别什么。安全研究也不只问平均回报是否提高，而要说明失败和约束如何定义、在什么信息条件下保证成立。这些方向长期交叉发展，表格按改变的条件分类，不主张它们构成严格的年代阶段。

例如仓储机器人可能只看到局部货架，只能先用旧仓库日志训练，到新仓库后还会遇到新的摩擦系数和协作机器人，同时必须避免碰撞。部分观测、离线数据、迁移、多智能体和安全约束在此叠加。一套标准在线控制

[15] L. P. Kaelbling, M. L. Littman, A. R. Cassandra, *Planning and Acting in Partially Observable Stochastic Domains* In Artificial Intelligence, 1998, vol. 101, no. 1–2, pp. 99–134

[16] P. F. Christiano, J. Leike, T. B. Brown, M. Martic, S. Legg, D. Amodei, *Deep Reinforcement Learning from Human Preferences* In Advances in Neural Information Processing Systems 30, 2017, pp. 4299–4307

[17] L. S. Shapley, *Stochastic Games* In Proceedings of the National Academy of Sciences, 1953, vol. 39, no. 10, pp. 1095–1100

[18] E. Altman, *Constrained Markov Decision Processes*, Chapman & Hall/CRC, 1999

改变的条件	标准问题之外的困难	承接位置
状态不完全可见	同一观测可对应不同状态，动作也可能用于获取信息	第 4章
训练经验固定	目标策略所需后果没有覆盖，不能随意补采	第 4章
奖励来自示范或偏好	行为意图未被直接观测，奖励可能不唯一或失配	第 5章
任务不再固定	目标、动力学或观测变化，经验复用可能产生负迁移	第 6章
多个参与者	回报与转移取决于共同选择和互相适应	第 7章
增加行为要求	期望收益不足以控制尾部失败、模型扰动或约束违反	第 8章

表 1.11 范围扩展改变的是标准设定中的条件，不只是网络结构。每行可以与其他行组合；按章分开讲解是为了辨认各条件造成的困难。

算法即使在仿真中表现良好，也没有逐项回答这些限制。下面的前沿方向正是在已有能力与这些尚未覆盖的条件之间寻找新的连接。

1.7.6 前沿研究方向

在一台机器人上学会选择动作，不意味着能将相同编号直接交给另一台机器人；编号可能对应不同关节，观测含义和奖励尺度也可能不同。跨任务预训练（cross-task pretraining）先利用多项任务的数据学习共享参数，再将其用于目标任务。为使共享有意义，需要对齐动作与观测接口，让同一网络处理不同模态的信息，并检查离线覆盖和新任务的适应条件。图像、语言与动作可以编码成统一词元，即序列中的输入输出单元，但编码形式相同不表示控制含义可以互换。

Gato 用统一序列组织多模态、多任务数据，由同一网络预测后续动作或词元，展示共享参数处理多种接口的可行性。其主要目标是拟合数据中的目标输出，属于监督式序列训练；样本来自轨迹不使它自动成为按奖励改进策略的方法。该工作已有 2022 年 TMLR 正式发表版本，结果须按训练任务、少量示范后的适应与未见任务泛化分别理解[19]。

参数共享之外，还可以让新任务经验直接进入网络输入。上下文强化学习（in-context reinforcement learning）在参数固定时，把这些经验放入上下文，用输入变化改变行为。发表于 ICLR 2026 的 S-ICQL 结合任务上下文中的价值估计与策略提取，也就是根据该估计产生动作规则。Vintix II 把决策预训练扩展到多领域，并分别考察在线与离线推断。表 1.12固定比较的维度为数据、接口与测试协议；在线推断可收集新反馈，离线推断只能使用给定上下文，任务数量不能代替信息预算的比较[20]。

同样发表于 ICLR 2026 的 Vintix II 报告了其留出任务集上的在线和离线推断结果。这些结果支持在所测任务族中研究上下文适应，不能推出任意任务上的保证。可复用结构、任务推断以及新任务需要多少交互，仍须在明确任务分布下讨论，第 6章将展开相关机制[21]。

跨任务方法需要复用决策知识，另一类方法则尝试先学习可供决策的环境预测。看起来连贯的视频不能直接回答“此刻改选另一动作会怎样”。

[19] S. Reed, K. Zolna, E. Parisotto, S. Gómez Colmenarejo, A. Novikov, G. Barth-Maron, M. Giménez, Y. Sulsky, J. Kay, J. T. Springenberg, T. Eccles, J. Bruce, A. Razavi, A. Edwards, N. Heess, Y. Chen, R. Hadsell, O. Vinyals, M. Bordbar, N. de Freitas, *A Generalist Agent* In Transactions on Machine Learning Research, 2022

[20] J. Liu, F. Liu, Z. Sun, J. Hao, H. Li, B. Wang, D. Dong, C. Chen, Z. Wang, *Scalable In-Context Q-Learning* In International Conference on Learning Representations, 2026

[21] A. Polubarov, N. Lyubaykin, A. Derevyagin, A. Grishin, I. Saprygin, A. Serkov, M. Averchenko, D. Tikhonov, M. Zhdanov, A. Nikulin, I. Zisman, A. Klepach, A. Zemtsov, V. Kurenkov, *Vintix II: Decision Pre-Trained Transformer is a Scalable In-Context Reinforcement Learner* In International Conference on Learning Representations, 2026

代表工作	训练任务与数据	可用动作与接口	测试时必须区分什么
Gato	游戏、控制、机器人及语言视觉数据；主要为监督式序列拟合	不同动作和文本经各自编码进入统一序列	训练任务、新对象或任务、提示示范与参数微调
S-ICQL	含次优历史数据的多任务预训练，结合价值学习	离散及连续任务；任务上下文与当前输入	已见与未见任务；在线反馈与固定日志提示
Vintix II	数百项多领域任务上的决策预训练	多种连续控制接口，经任务相关编码对齐	留出任务划分；在线累积反馈或离线给定示范

表 1.12　跨任务决策工作的比较口径。表中描述各原工作采用的接口，不表示一个模型无需适配就能执行任意新动作；预训练规模、测试交互和参数更新预算应分别报告。

世界模型（world model）在这里指从观测学习的环境动态表示与预测机制，用它预测动作之后的变化。要支持控制，还需预测任务反馈，并处理模型滚动：把一次预测作为下次预测的输入，连续模拟未来。旧行为数据中的预测准确，不保证优化器主动寻找的新动作序列也预测准确。

DreamerV3 在内部表示上学习动态，用模型生成想象轨迹，即未经真实环境执行的预测轨迹，并在其中训练行动者和评论家。其正式版本于 2025 年发表于 Nature，题名为 *Mastering diverse control tasks through world models*。比较条件是使用同一套超参数在多个领域分别训练，不是一个冻结策略解决所有未见领域。像素与低维输入、训练预算及各基准设置仍须按原文区分[22]。

TD-MPC2 在学习模型内进行局部轨迹优化，即每次决策先比较一段候选未来，再执行当前动作。其 ICLR 2024 正式记录包含单任务在线控制及多任务模型实验。DreamerV3 主要在想象轨迹中训练可执行的策略，TD-MPC2 则在真实决策时继续规划，两者的计算支出位置不同。它们都面对模型误差，却不能因共用世界模型就视为相同接口[23]。

图 1.14将模型内求解接回真实环境，用虚线单独标出校准路径。在线协议允许用新经验修正模型；纯离线协议不能追加真实训练数据，真实执行只用于评价。若继续用评价数据训练，就改变了访问协议。

Dreamer 4 的 2025 年原始预印本（arXiv:2509.24527v1）研究从离线数据学习可交互世界模型，在模型内训练行为，再在 Minecraft 中评价。它的特定任务结果属于前沿证据，不能据此断言视频模型能可靠回答一般物理反事实，即同一情境下未执行动作会产生什么结果，也不能据此证明真实机器人部署安全[24]。

工具使用也形成长期交互，但它的动作与时间单位需重新指定。设任务是修复一段程序并通过测试：智能体读文件、运行测试、修改代码、观察失败，必要时回退重试。语言输出可能只是工具参数，一次工具调用才是环境动作，完整修复任务是一个回合。若改以词元为动作，就须在更细尺度解释奖励归属；若以整次调用为动作，则须记录执行后的状态变化、耗

[22] D. Hafner, J. Pasukonis, J. Ba, T. Lillicrap, *Mastering Diverse Control Tasks through World Models* In Nature, 2025, vol. 640, no. 8059, pp. 647–653

[23] N. Hansen, H. Su, X. Wang, *TD-MPC2: Scalable, Robust World Models for Continuous Control* In International Conference on Learning Representations, 2024

[24] D. Hafner, W. Yan, T. Lillicrap, *Training Agents Inside of Scalable World Models* In arXiv preprint arXiv:2509.24527, 2025

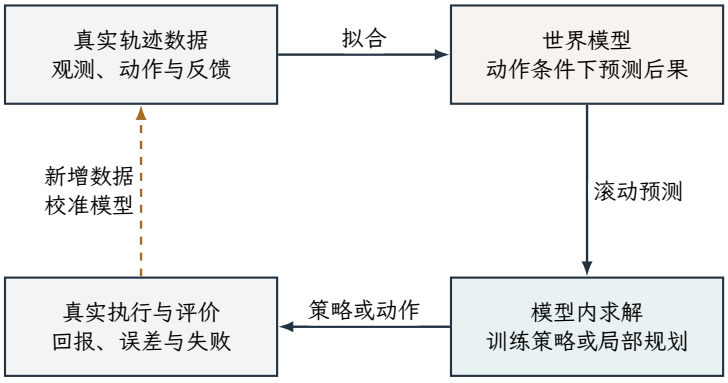


图 1.14 可供决策使用的世界模型闭环。实线是训练与真实评价的信息依赖；虚线返回边只在协议允许新增真实训练数据时存在。模型内高回报必须在真实环境上检验，不能由视频逼真度代替。

时与反馈。两种设定仍可使用行动与回报的区分，但步数的单位已变，不能直接比较样本效率。

此类交互还要求记忆已做过什么、识别外部反馈是否可信，以及在错误改变环境之后恢复。最终测试通过只提供一个稀疏信号，无法直接说明哪次修改有益；工具输出只是局部观测，也不保证整个软件环境可见。Agent Lightning 的 2025 年预印本尝试把智能体执行与强化学习训练解耦，以统一经验接口处理复杂工作流中的信用分配[25]。它在文本到 SQL、检索增强生成与数学工具任务上的报告应绑定原文协议，不能把框架名称中的“ANY”当作所有智能体上的验证结论。

2026 年的后续预印本 Agent Lightning v1.0 把部署时管理工具、上下文与控制流的运行框架进一步纳入训练，并讨论重分词、样本合并与优势计算。这些处理分别涉及词元划分、执行记录的组装与动作相对基线的评分，影响学习数据与实际工作流怎样对应。评价长期任务智能体时，须固定工具权限、可访问文件、调用预算、上下文长度、重试次数与重置方式，否则成功率提高可能只来自更多信息或计算。系统工程细节由系统卷承接，本部分用信用分配、部分观测和反馈构造解释学习条件[26]。

行为模型的预测还面临一个识别问题：日志中的关联能否确定强制改变动作后的结果？因果机制学习（causal mechanism learning）尝试描述变量怎样产生结果，以回答这类干预问题。我们用一个二元教学例检验所需信息。动作 A 和结果 Y 均取 0 或 1，隐藏变量 U 以各一半概率取 0 或 1。机制甲为 $A = U, Y = A$，机制乙为 $A = U, Y = U$。两者观察日志都满足 $\mathbb{P}(A = Y) = 1$，但强制令 $A = 1$ 时，甲总有 $Y = 1$，乙仍以一半概率得 $Y = 0$。相同观察分布因此不能确定干预后的结果。

[25] X. Luo, Y. Zhang, Z. He, Z. Wang, S. Zhao, D. Li, L. K. Qiu, Y. Yang, *Agent Lightning: Train ANY AI Agents with Reinforcement Learning* In arXiv preprint arXiv:2508.03680, 2025

[26] Z. He, S. Zhang, Z. Zhou, Y. Yang, Y. Kang, Y. Zhang, L. K. Qiu, T. Y. Tsui, J. Xu, C. Luo, *Agent Lightning v1.0: Towards Harnessed Agentic RL* In arXiv preprint arXiv:2608.17528, 2026

干预分布之外，反事实还问同一个体在另一动作下会怎样。即使各动作的转移分布已知，这些潜在结果如何共享随机因素，也未必由 MDP 核唯一确定；这种共同随机关系称为耦合（coupling）。Oberst 与 Sontag 用 Gumbel-Max 结构因果模型构造反事实轨迹，通过指定变量生成关系与耦合来回答问题。所得解释依赖这些假设，不是从任意离线日志无条件识别全部反事实的定理[27]。

[27] M. Oberst, D. Sontag, *Counterfactual Off-Policy Evaluation with Gumbel-Max Structural Causal Models* In Proceedings of the 36th International Conference on Machine Learning, 2019, pp. 4881–4890

若希望复用机制，还须说明任务间哪些生成关系不变、哪些变量可被干预、数据覆盖哪些情况，以及这些假设是否足以确定目标量，这就是可识别性（identifiability）要求。组合泛化（compositional generalization）将已学组成用于未见组合；若新任务拼接了从未共同出现的机制，还需验证原转移关系是否在拼接后保持。世界模型预测、预训练规模与工具执行能力各自提供不同能力，不能自动补齐识别条件。后续各章将在具体信息与访问条件下讨论能够学到什么。

1.8 本章小结

回到网格任务，决策问题现在有了可核算的说明。状态是除障碍外的格子，合法命令按意图方向确定，环境以 0.8/0.1/0.1 执行或滑移；起点、终点吸收与奖励规则固定。给出一份策略，就能由动作概率与环境核计算轨迹概率，再用占用度量汇总折扣时间中的状态动作分布。回报给这些轨迹计长期总分，价值则在行动前按可能后果取平均。策略改变的既是长期回报，也是后续经验的来源。

章首的机器人因此不能只按当前距离选择动作：距离变小，并不能保证整段行动到达目标，更不能保证安全。比较行动需指定后继分布、长期评分和后续规则；从经验作出比较，还需检查数据是否支持待选行为。本章给出了描述和评价这些关系的对象，尚未求出仓储任务的最优安全路线。表 1.13用三个具体判断收拢易混对象，便于继续检查求解方法与实验结论。

区别	可用于检验理解的具体判断
状态与观测	相同照片可能对应门已开或未开；照片不一定是充分状态。见第 1.1.2节。
奖励样本与长期价值	$(3,3)$ 向右的一次奖励是 1 或 -0.04；两步 $Q_0^{\pi} = 0.85968$ 是多种未来的平均。见第 1.5.1节。
行为与目标策略	日志始终向左，不代表待评价策略也应向左；右行的后果仍可能缺证据。见第 1.3.2节。

表 1.13　对象不同，能够回答的问题也不同。数值判断沿用本章明确给出的两步算例，不能移作无限时域结论。

有界奖励与 $0 \le \gamma < 1$ 保证了折扣回报存在，也给出截断尾项界；有限时域和无限折扣下的条件期望论证则说明价值满足递推。价值存在和满足

递推，还不意味着已经有可承受的求解方法，也不意味着有限数据能估计得足够准。第 2章先在模型可访问时建立规划与计算误差基准，区分精确期望和指定查询点的随机采样；第 3章再处理未知环境中的经验收集、估计与策略改进。历史和前沿中的方法虽然扩展了表示与接口，结论仍须绑定目标、信息和访问条件，因为行动始终同时改变结果与学习证据。

第 2 章

给定模型下的规划

第 1 章用随机滑移的网格说明了为何要比较动作的长期后果，也证明了回报期望满足 Bellman 递推。现在假设导航模型已经给出：我们能够查询每个合法动作会把机器人带到哪里，以及会得到什么奖励。待求的不再是环境规律，而是怎样利用这些规律算出一份策略。一次查询只涉及一个状态动作，策略却要应对后续可能到达的许多状态；列出所有后果、保存价值和达到所需精度，都要消耗计算资源。

使用同一环境模型，还要区分它允许我们取得什么答案。给定一个后继价值估计 v，比较当前动作需要计算当步期望奖励与折扣后继价值之和。**精确期望访问**（exact expectation access）允许直接计算 $R(s,a)+\gamma\sum_{s'}P(s'\mid s,a)v(s')$。网格模型若列出向前和向两侧滑移的全部概率，就能按这些概率加权求和。**生成模型访问**（generative model access）只允许指定任意合法的 (s,a)，再取得一个独立样本 $(r,s')\sim p(\cdot,\cdot\mid s,a)$，相当于反复调用模拟器。重复同一查询可能得到不同后果，规划器只能用样本均值估计上述期望。

生成模型无须公开概率表，也不要求规划器先从起点走到 s；它提供的是从指定查询点正确采样的能力。因此，模型准确并不意味着有限次查询已经给出准确期望。本章把两种接口都作为给定资源，在各方法中分别说明所需能力。尤其不能把真实机器人的交互默认成生成模型：机器人通常只能从当前位置继续行动，不能任意重置到待查状态。后面的稀疏采样规划依赖这种指定查询点的能力[1]。

我们先沿用前章的有限折扣 MDP：状态、动作集合有限，每个 $\mathcal{A}(s)$ 非空，$|r_t|\le R_{\max}$，且 $0\le\gamma<1$。奖励 r_t 仍按执行 a_t 的时刻编号，价值和策略性能仍是未归一化折扣回报。前章的有界回报结论于是给出 $|V^{\pi}(s)|\le V_{\max}:=R_{\max}/(1-\gamma)$。讨论有限时域、成本最小化或平均奖励时，我们会在当地重新规定目标，避免把这些设定混入折扣结论。

在这些条件下，Bellman 动态规划逐状态使用递推，全局优化则同时约束所有状态动作；两条路线求解同一目标。额外的动力学、成本或独立性结构，有时还能减少精确求解所需的未知量或动作比较，但必须逐项验证

[1] M. Kearns, Y. Mansour, A. Y. Ng, *A Sparse Sampling Algorithm for Near-Optimal Planning in Large Markov Decision Processes* In Machine Learning, 2002, vol. 49, pp. 193–208

其条件。若状态数或搜索树仍超出预算，可以只为当前状态展开局部后果，也可以保存一份跨状态复用的近似价值。局部搜索还可用这份价值评估未展开的未来，所以两类近似能够配合。图 2.1 展示的正是这些求解方式及其联系，后文再用误差和资源要求比较它们。

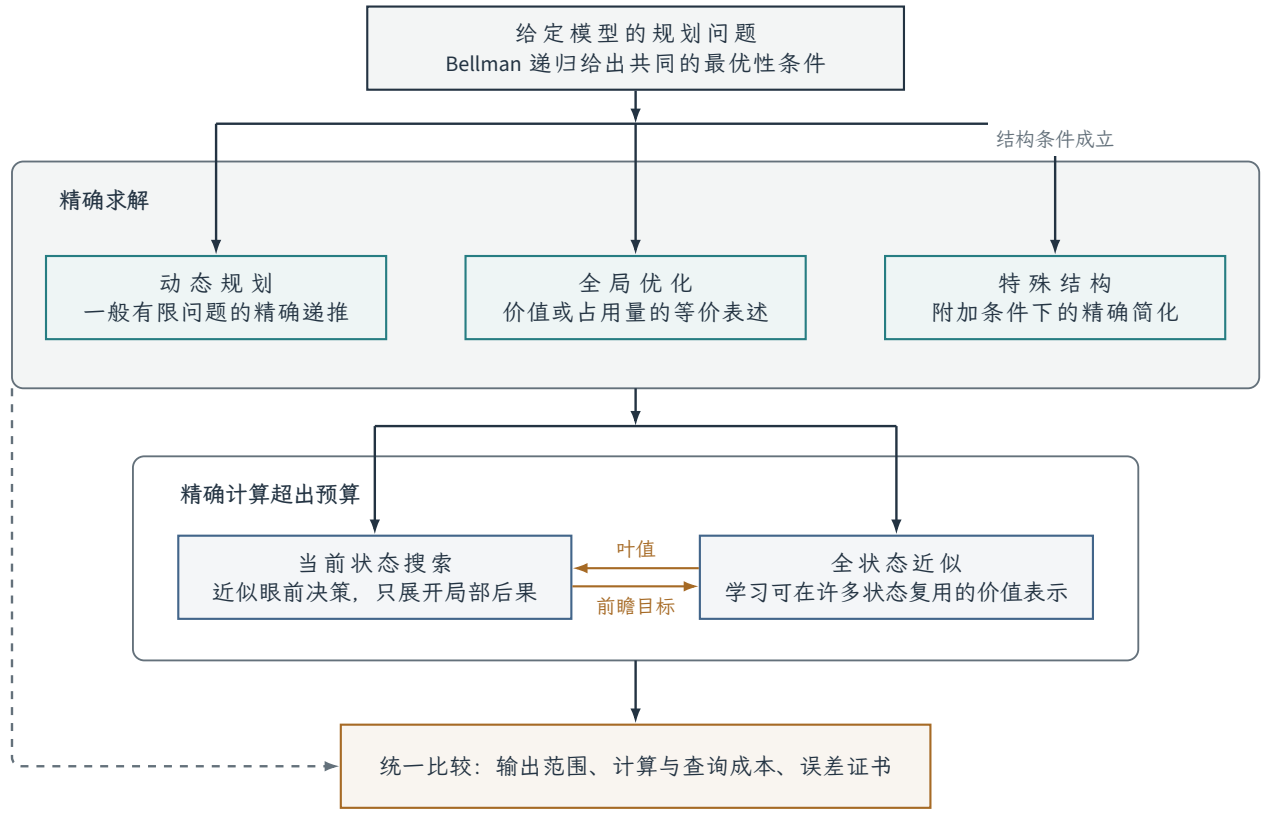


图 2.1　给定模型时的规划方法关系。动态规划与全局优化是一般精确路线；特殊结构只在附加条件成立时给出精确简化。精确计算超出预算后，可以近似当前决策或构造全状态近似，二者可通过叶节点价值与前瞻目标结合。

2.1　Bellman 动态规划

在网格的一个岔路口，若已知各后继状态的价值，就能用当步奖励和后继价值比较合法方向。动态规划（dynamic programming）反复利用这种一步分解，逐步求出原先未知的长期价值。我们先固定动作规则，计算遵从它的后果；再用这个评价比较其他动作，最后把动作选择直接并入价值更新。

2.1.1 策略评价

给定平稳策略 π，策略评价要算的是每个状态出发的 V^π，而不是重新选择动作。为把前章的 Bellman 关系写成线性方程，先按 π 平均当步奖励和转移概率：

$$r^\pi(s)=\sum_a \pi(a\mid s)R(s,a),\qquad P^\pi(s,s')=\sum_a \pi(a\mid s)P(s'\mid s,a).$$

这样得到的 r^π 是当步期望奖励，并非一次模拟的实现值；P^π 描述遵从 π 时下一状态的分布。在精确期望接口下，按状态排列的 $\boldsymbol{r}^\pi$ 和 $\boldsymbol{P}^\pi$ 都已经确定，只有价值向量待求。令 $\boldsymbol{v}^\pi$ 的 s 坐标为 $V^\pi(s)$，便有

$$\boldsymbol{v}^\pi=\boldsymbol{r}^\pi+\gamma\boldsymbol{P}^\pi\boldsymbol{v}^\pi,\qquad (\boldsymbol{I}-\gamma\boldsymbol{P}^\pi)\boldsymbol{v}^\pi=\boldsymbol{r}^\pi. \tag{2.1}$$

矩阵 $\boldsymbol{P}^\pi$ 非负且每行之和为 1，其无穷范数，即最大绝对行和，为 1。结合 $\gamma<1$，矩阵级数 $\sum_{k\ge 0}\gamma^k(\boldsymbol{P}^\pi)^k$ 收敛，并给出 $\boldsymbol{I}-\gamma\boldsymbol{P}^\pi$ 的逆。将级数乘奖励向量后，每一项才给出对应时刻的折扣期望奖励，因此直接解方程与按时间累积奖励得到的是同一个 V^π。

示例 2.1　三个格子的独立手算模型　为看清线性方程如何计入反复停留，我们另设一条 x,y,g 三格走廊，从 x 开始。它不是宽 4、高 3 基准网格的局部转移表：非终点只有“前进”和“等待”，前进以 0.8 进入下一格、以 0.2 留在原处，等待则必定原地不动，不再有侧向滑移。g 保留零奖励吸收动作。进入 g 仍得 1，其余非终点步仍得 -0.04，并取 $\gamma=0.9$。

固定总是前进的策略，按 x,y,g 排序有

$$\boldsymbol{P}^\pi=\begin{pmatrix}0.2 & 0.8 & 0\\ 0 & 0.2 & 0.8\\ 0 & 0 & 1\end{pmatrix},\qquad \boldsymbol{r}^\pi=\begin{pmatrix}-0.04\\ 0.792\\ 0\end{pmatrix}.$$

在 y 前进只有 0.8 概率进入终点，所以第二个期望奖励为 $0.8\times1+0.2\times(-0.04)=0.792$，不是每次都得 1。终点以后没有奖励，故 $V^\pi(g)=0$；把原地停留项移到左侧，得到

$$0.82V^\pi(y)=0.792,\qquad 0.82V^\pi(x)=-0.04+0.72V^\pi(y),$$

因而

$$V^\pi(y)=\frac{198}{205}\approx 0.965854,\qquad V^\pi(x)=\frac{6718}{8405}\approx 0.799286.$$

也可以从 $v^{(0)}=0$ 开始，每轮都用上一轮的整张表计算新值。前两轮在 (x,y) 处依次得到 $(-0.04,0.792)$ 与 $(0.52304,0.93456)$。这种同步备份第一轮只计当步奖励，第二轮才把 y 处的已有价值传到 x。

走廊中的同步计算可以用于所有状态：Bellman 备份（Bellman backup）用已有后继价值重算当前的一步期望。为表示对整张价值表做一次备份，定义策略算子

$$(T^{\pi}v)(s)=r^{\pi}(s)+\gamma\sum_{s'}P^{\pi}(s,s')v(s'). \tag{2.2}$$

反复使用 T^{π} 后，初值是否还会影响答案？我们用无穷范数衡量最大状态误差，即在所有状态中取绝对误差的最大值；再次备份后不变的价值表则称为固定点。下面先证明误差每轮缩小、固定点唯一，再把可计算的备份差转成停止依据。

定理 2.2　策略评价的压缩性与收敛　在上述有限折扣条件下，T^{π} 在无穷范数下为 γ 压缩映射，其唯一固定点为 V^{π}。同步迭代 $v^{(k+1)}=T^{\pi}v^{(k)}$ 满足

$$\|v^{(k)}-V^{\pi}\|_{\infty}\le\gamma^{k}\|v^{(0)}-V^{\pi}\|_{\infty}.$$

证明　对任意 v,u 和状态 s，期望奖励相消，故

$$\begin{aligned}|(T^{\pi}v)(s)-(T^{\pi}u)(s)|&\le\gamma\sum_{s'}P^{\pi}(s,s')|v(s')-u(s')|\\&\le\gamma\|v-u\|_{\infty}.\end{aligned}$$

第一个不等式来自概率非负，第二个来自概率之和为 1：加权平均不会放大最大坐标差。对 s 取最大值，便说明备份把两张表的距离缩至原来的至多 γ 倍，这就是压缩性。有限维实向量空间在此范数下完备，压缩映射定理保证唯一固定点和迭代收敛。前章已由回报分解证明 V^{π} 满足式 (2.2)，因此固定点就是所求价值。每轮把 $v^{(k)}$ 与 V^{π} 代入压缩不等式，连续使用 k 次即得误差界。 ■

迭代界还含未知的初始真实误差。实际计算时，我们更容易检查一张表再次备份后改变了多少；这项变化也能控制它离 V^{π} 还有多远。

定理 2.3　评价残差证书　对任意有界 v，

$$\|v-V^{\pi}\|_{\infty}\le\frac{\|T^{\pi}v-v\|_{\infty}}{1-\gamma}. \tag{2.3}$$

证明 插入 $T^\pi v$ 并利用固定点关系，有

$$\begin{aligned}\|v - V^\pi\|_\infty &\le \|v - T^\pi v\|_\infty + \|T^\pi v - T^\pi V^\pi\|_\infty \\ &\le \|v - T^\pi v\|_\infty + \gamma \|v - V^\pi\|_\infty .\end{aligned}$$

将右边的真实误差项移到左侧，再除以正数 $1-\gamma$，就把未知价值误差界在了可计算的备份差之内。 ■

这项备份差称为Bellman 残差（Bellman residual）：$T^\pi v - v$ 表示当前预测与其一步递推要求还差多少。精确模型可以算出它，而无须先知道真实价值。要让每个状态的价值误差都不超过 ε，只需确认全状态残差的无穷范数不超过 $(1-\gamma)\varepsilon$。抽查少量状态或用样本估计残差，还不能给出同样的证书，必须另外控制未查状态和估计误差。

同步备份为每个状态保留同一轮旧值。Gauss–Seidel 更新则按顺序覆盖表，后更新的状态可以立即使用本轮较新的后继值；异步更新进一步允许一次只处理部分状态。对精确备份，收敛的一个充分条件是每个状态都无限次更新，且所用信息不会永久停留在旧时刻；有界延迟是常用的更强条件。证明按所有状态都完成有效更新划分阶段，逐阶段缩小覆盖全状态的误差上界。优先处理大残差可能节约工作，但不能取消持续更新每个状态的要求，否则遗漏状态的误差还会传给前驱。标准处理可参见 Sutton 与 Barto 教材第 4 章[2]。

[2] R. S. Sutton, A. G. Barto, *Reinforcement Learning: An Introduction*, MIT Press, 2018, 2nd ed.

2.1.2 策略改进与迭代

有了 V^π，可以重新检查网格中的方向选择。向左绕回起点与向终点移动，当步奖励可能同为 -0.04，长期后果却不同。我们先只改变当前这一步，以后仍遵从 π；这样既能比较新动作，又能沿用刚算出的后继价值：

$$Q^\pi(s,a) = R(s,a) + \gamma \sum_{s'} P(s' \mid s,a) V^\pi(s').$$

目标是提高期望折扣回报，因此我们在合法集合 $\mathcal{A}(s)$ 中选择 Q^π 最大的动作。

定义 2.4 贪心策略 相对于 Q^π 的贪心策略只在最大化动作集合

$$\arg\max_{a \in \mathcal{A}(s)} Q^\pi(s,a)$$

中选择动作。确定性选择每个状态的一个最大化动作，随机选择可以在这些动作间分配任意概率。策略迭代采用确定性规则：若旧动

作仍达到最大值，就保留旧动作；否则按预先固定次序选一个最大化动作。

这样的“贪心”比较包含未来回报，并非只看即时奖励。剩下要证明的是：Q^π 只评价当前一次偏离，却能支持以后每一步都遵从新规则，而不降低真实价值。

定理 2.5　策略改进及策略迭代的有限终止　若平稳策略 π' 满足 $T^{\pi'}V^\pi \geq V^\pi$ 逐状态成立，则 $V^{\pi'} \geq V^\pi$。在有限折扣 MDP 中，采用精确评价、确定性贪心改进和上述保留并列旧动作规则的策略迭代，有限步终止于全状态最优策略。

证明　非负转移概率保证备份保持逐状态大小关系：$u \geq v$ 就有 $T^{\pi'}u \geq T^{\pi'}v$，这称为算子的单调性。对假设中的不等式反复使用同一个 $T^{\pi'}$，

$$V^\pi \leq T^{\pi'}V^\pi \leq (T^{\pi'})^2 V^\pi \leq \cdots.$$

定理 2.2 说明右端收敛到 $V^{\pi'}$，所以逐状态不等式在极限中仍成立。

贪心改进满足 $T^{\pi'}V^\pi \geq T^\pi V^\pi = V^\pi$。若策略改变，保留并列旧动作的规则保证至少某个状态 s 有 $(T^{\pi'}V^\pi)(s) > V^\pi(s)$；上述单调序列又说明 $V^{\pi'}(s) \geq (T^{\pi'}V^\pi)(s) > V^\pi(s)$。因此策略未终止时，价值向量至少一个坐标严格增加，其他坐标不减，不可能回到以前的策略。确定性平稳策略至多有 $\prod_s |\mathcal{A}(s)|$ 个，故必在有限步停止。

有限终止还不够，我们必须检查终止策略是否支配所有允许的行为。停止意味着旧动作已是最大化动作，所以对于所有 s, a，

$$V^\pi(s) \geq R(s,a) + \gamma \sum_{s'} P(s' \mid s,a) V^\pi(s').$$

对任意可能依赖历史的策略 σ，将该不等式沿它的动作与转移取条件期望并连续展开 H 步，得到

$$V^\pi(s) \geq \mathbb{E}_\sigma\left[\sum_{t=0}^{H-1} \gamma^t r_t + \gamma^H V^\pi(s_H) \,\middle|\, s_0 = s\right].$$

有界价值乘 γ^H 后趋于 0，故 $H \to \infty$ 时有 $V^\pi(s) \geq V^\sigma(s)$。这里没有把 σ 限制成平稳或确定性策略；它任意而 π 自身可行，因而终止策略在所有状态最优。 ■

算法 2.1 精确策略迭代

输入： 精确模型，$\gamma < 1$，确定性初始策略 $\pi^{(0)}$
输出： 全状态最优确定性平稳策略

for $k = 0, 1, \dots$ **do**
  解 $(\boldsymbol{I} - \gamma \boldsymbol{P}^{\pi^{(k)}})\boldsymbol{v} = \boldsymbol{r}^{\pi^{(k)}}$
  for 每个状态 s **do**
    计算 $q(s,a) = R(s,a) + \gamma \sum_{s'} P(s' \mid s,a) v(s')$
    在最大化动作中保留旧动作，否则按固定次序选取 $\pi^{(k+1)}(s)$
  end for
  if $\pi^{(k+1)} = \pi^{(k)}$ **then**
    return $\pi^{(k)}$
  end if
end for

算法 2.1 把上述证明对应的评价与改进组成一个循环。为观察不同位置怎样先后改变动作，我们回到未简化的基准网格：起点 $(1,1)$、终点 $(4,3)$、障碍 $(2,2)$，意图方向概率 0.8、两侧滑移各 0.1；非法意图方向被排除，滑移撞墙仍留在原处。表 2.1 按“左、下、右、上”取每个状态第一个合法动作为 $\pi^{(0)}$，并使用同一次序处理需要换动作的并列选择，列出两轮精确评价和改进。终点仅有零奖励吸收动作，故省略其行。

状态	$\pi^{(0)}$	$\pi^{(1)}$	$\pi^{(2)}$	$V^{\pi^{(0)}}$	$V^{\pi^{(1)}}$	$V^{\pi^{(2)}}$
$(1,1)$	右	右	右	-0.400000	0.393318	0.395377
$(2,1)$	左	右	右	-0.400000	0.515595	0.517970
$(3,1)$	左	右	右	-0.398373	0.642761	0.645466
$(4,1)$	左	上	上	-0.383549	0.769713	0.771194
$(1,2)$	下	下	下	-0.400000	0.296572	0.298380
$(3,2)$	下	右	上	-0.383549	0.785763	0.801271
$(4,2)$	左	上	上	-0.246674	0.948042	0.949576
$(1,3)$	下	下	右	-0.400000	0.268198	0.606648
$(2,3)$	左	右	右	-0.400000	0.783647	0.784994
$(3,3)$	左	右	右	-0.398373	0.948042	0.949576

表 2.1 基准随机网格的两轮策略改进。每列价值均解完整线性方程后四舍五入至六位小数，不是轨迹样本均值。$\pi^{(2)}$ 尚未声称最优，下一轮仍需重新检查贪心条件。

初始策略把左侧区域封闭起来，进入后会一直付出步成本，因此这些状态的价值为 $-0.04/(1-0.9) = -0.4$。第一轮已使 $(2,1)$ 转向右，$(1,3)$ 却仍保留向下：在旧策略的评价中，右邻还会把机器人带回左侧。第二轮用改进后的后继价值重算，才使 $(1,3)$ 转向右。这说明后续行为的改善如何传到前面的选择，也说明一次改进未必足以恢复最终路线。

每轮都解完评价方程可能耗费较多计算，于是可以限制评价的备份次数，再利用当前结果改动作。表 2.2 比较这种安排与精确评价，并说明修改策略迭代把部分评价放在循环的哪个位置。**广义策略迭代**（generalized

policy iteration）概括评价与改进相互影响的过程；它命名的是这种配合关系，并不保证任意不精确的交替都使真实性能单调增加。

安排	每次评价工作	何时改进
精确评价	解方程；理论上也可迭代至极限	得到 V^{π} 后
部分评价	固定若干次备份或达到指定残差	评价预算用尽时
修改策略迭代	从当前 v 选贪心策略，再做 $m_k \geq 1$ 次该策略备份	每个外层循环一次

表 2.2　评价深度与改进频率。部分评价是一类操作，修改策略迭代是将它嵌入明确循环的算法；两者不是互斥类别。

2.1.3 价值迭代

策略迭代要先评价一份完整策略，才能用其价值改进。如果我们只想逐轮逼近最优价值，也可以在每次备份时立即比较所有合法动作，保留当步奖励加后继估值最大的结果。这样不再等待一份策略被完整评价，动作选择直接成为更新的一部分。

定义 2.6　最优 Bellman 算子　对任意状态函数 v，定义

$$(T^{*}v)(s) = \max_{a \in \mathcal{A}(s)} \left\{ R(s,a) + \gamma \sum_{s'} P(s' \mid s,a) v(s') \right\}. \tag{2.4}$$

相对于 v 的贪心策略 π_v 选择该式的最大化动作，因此 $T^{\pi_v} v = T^{*} v$。

定理 2.7　最优固定点与平稳最优策略　有限折扣 MDP 的 T^{*} 单调且为 γ 压缩映射。其唯一固定点为 V^{*}，并且存在确定性平稳策略 π^{*}，对每个初始状态及所有历史依赖随机策略都达到最优价值。

证明　若 $v \leq u$，每个动作的期望备份都不减，取最大值后仍有 $T^{*}v \leq T^{*}u$。对有限个实数 $\{f_a\}, \{g_a\}$，取 f_a 的最大化动作 a_f，有 $\max_a f_a - \max_a g_a \leq f_{a_f} - g_{a_f} \leq \max_a |f_a - g_a|$。交换两组数便得最大值之差的绝对值界。因此

$$\| T^{*}v - T^{*}u \|_{\infty} \leq \gamma \| v - u \|_{\infty}.$$

压缩映射定理给出唯一固定点 $\bar{v}$。有限动作集保证每个状态都能取到一个最大化动作，组成确定性平稳策略 $\bar{\pi}$。于是 $T^{\bar{\pi}} \bar{v} = T^{*} \bar{v} = \bar{v}$，策略评价固定点的唯一性给出 $\bar{v} = V^{\bar{\pi}}$。

还须证明 $\bar{v}$ 不只是平稳策略中的某个值。固定点对每个动作给出 $\bar{v}(s) \geq R(s,a) + \gamma \mathbb{E}[\bar{v}(s') \mid s, a]$。沿任意历史依赖随机策略逐步取条件期望，展开 H 步，

$$\bar{v}(s) \geq \mathbb{E}\left[\sum_{t=0}^{H-1} \gamma^t r_t + \gamma^H \bar{v}(s_H) \,\middle|\, s_0 = s \right].$$

$\bar{v}$ 在有限状态集上有界，尾项趋于 0，故 $\bar{v}$ 支配每个策略的价值。另一方面 $\bar{\pi}$ 实现它，因此 $\bar{v} = V^*$，取 $\pi^* = \bar{\pi}$ 即得结论。 ■

价值迭代（value iteration）反复执行 $v^{(k+1)} = T^* v^{(k)}$，用当前后继估值计算下一轮的最大一步备份。由压缩性，$\|v^{(k)} - V^*\|_\infty \leq \gamma^k \|v^{(0)} - V^*\|_\infty$。若不使用含初始误差的轮数界，也可以再次检查备份差。按评价残差证明插入 $T^* v$ 并移项，得到

$$\|v - V^*\|_\infty \leq \frac{\|T^* v - v\|_\infty}{1 - \gamma}. \tag{2.5}$$

同步更新时，$v^{(k+1)} - v^{(k)}$ 恰好是旧表 $v^{(k)}$ 的残差，因此其无穷范数能为旧表提供证书。若实际返回新表，则应检查新表的残差，或另行推导它的界；两张表对应的索引不能混用。

价值表接近 V^* 之后，还要从表中选动作并执行。执行策略的损失是其真实价值与 V^* 之差，不是表本身的预测误差；近似表还会影响以后每一次选择。下面把全状态价值精度转成长期执行的性能界。

定理 2.8　由价值精度到贪心策略性能　若 $\|v - V^*\|_\infty \leq \varepsilon$，且 π_v 通过精确模型对 v 贪心，则

$$\|V^* - V^{\pi_v}\|_\infty \leq \frac{2\gamma\varepsilon}{1 - \gamma}. \tag{2.6}$$

证明　利用 $T^* v = T^{\pi_v} v$，在 $T^* V^* - T^{\pi_v} V^{\pi_v}$ 中插入这两个相等的量，有

$$\begin{aligned} \|V^* - V^{\pi_v}\|_\infty &\leq \|T^* V^* - T^* v\|_\infty + \|T^{\pi_v} v - T^{\pi_v} V^{\pi_v}\|_\infty \\ &\leq \gamma\varepsilon + \gamma \|v - V^{\pi_v}\|_\infty \\ &\leq 2\gamma\varepsilon + \gamma \|V^* - V^{\pi_v}\|_\infty. \end{aligned}$$

第一项 $\gamma\varepsilon$ 控制最优备份受到估值误差的影响，第二项再计入同一表与执行策略价值的差。将最后的策略损失移到左侧即得结论，因此该界覆盖反复执行 π_v，而不只覆盖根动作。 ■

先用残差界控制价值误差，再代入贪心性能界，可知全状态最优残差为 η 时，精确贪心策略的损失至多 $2\gamma\eta/(1-\gamma)^2$。这也给出了按策略精度选择停止阈值的依据。若 $\gamma = 0$，未来不再计入目标，直接最大化即时奖励已精确最优，不需要含 $1/\gamma$ 的阈值。

图 2.2 固定基准网格和零初值，展示终点收益怎样随精确备份向远处传播。终点值始终为 0，因为奖励 1 已经在进入它的那一步支付；若再把终点值设为 1，就会重复计奖。第一轮邻近终点的最大期望奖励为 0.792，更远状态则在后续轮次中才计入这项收益。

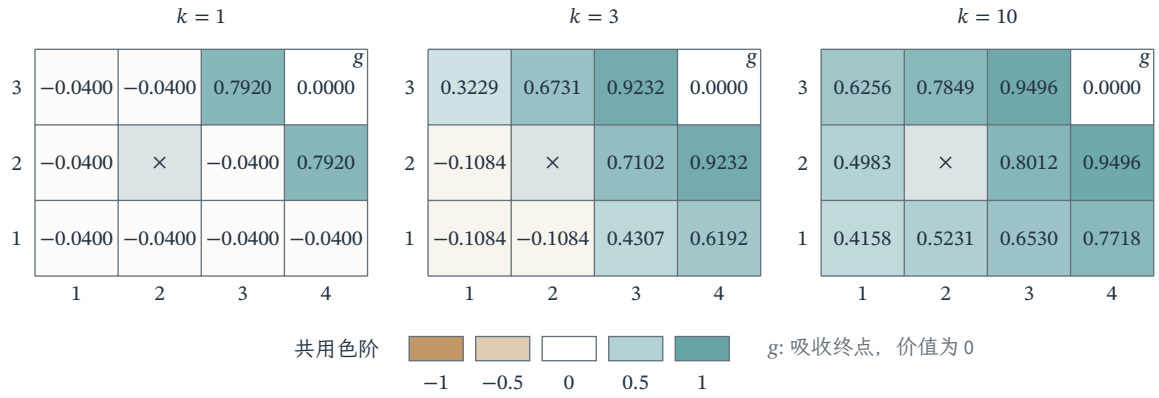


图 2.2 基准随机网格在 $k = 1, 3, 10$ 次同步价值迭代后的价值，$\gamma = 0.9$、$v^{(0)} = 0$。数字由完整转移期望计算，显示四位小数；三个面板共用色阶，障碍单独标记。它们是确定的算法迭代值，不是实验学习曲线。

上述迭代和证书依赖折扣压缩性。若目标只计有限步，我们可以从指定终端值反向算，不需要令迭代趋于无限；若改用平均奖励，累计收益通常不断增长，原价值固定点也不再适用。表 2.3 对照这三种任务。在存在共同最优平均奖励 g 的条件下，差分价值 $h(s)$ 衡量扣除共同增长趋势后的状态差别，只确定到一个加法常数；表中 $P_a h(s) = \sum_{s'} P(s' \mid s, a) h(s')$。这些时间目标及其条件可见 Puterman 的系统论述[3]。

[3] M. L. Puterman, *Markov Decision Processes: Discrete Stochastic Dynamic Programming*, John Wiley & Sons, 1994

目标	递推与边界	关键条件与保证
有限时域	$V_H = 0$，$V_t = T_t^* V_{t+1}$；无折扣时取该式 $\gamma = 1$	反向做 H 层；策略一般随 t 变化
无限折扣	$V^* = T^* V^*$	有限状态动作、奖励有界、$\gamma < 1$；无穷范数压缩
平均奖励	$g + h(s) = \max_a \{R(s,a) + P_a h(s)\}$	需另给通信等条件以得到共同增益 g；相对价值迭代收敛还需相应非周期或更强混合条件

表 2.3 不同时间目标的递推口径。平均奖励相对价值迭代通常每轮减去参考状态的备份值来固定 h 的常数，但不能直接套用 $\gamma < 1$ 的证明。

2.2 从动态规划到全局优化

刚才我们逐状态备份，靠收敛得到最优价值。对同一个有限折扣 MDP，也可以把所有状态动作应满足的关系一次写成约束，再交给优化器求解。未

知量既可以是各状态的价值，也可以是策略在折扣时间内分配给各状态动作的访问量。前者限制长期回报的上界，后者限制哪些访问分布确实能够实现；下面把二者写成互相对应的原始与对偶优化问题。

2.2.1 价值的线性规划

最优 Bellman 方程说明：在状态 s 先取任意合法动作，再最优行动，回报都不能超过 $V^*(s)$。我们据此要求候选函数 v 满足 $v(s) \ge R(s,a) + \gamma \sum_{s'} P(s' \mid s,a) v(s')$，对每个状态动作都成立。下一项证明将说明这些约束使 v 成为 V^* 的逐状态上界。既然上界可以任意抬高，我们应将它压低，而不是最大化它。用非负权重 $w(s)$ 指定各状态在目标中的分量，目标和约束都关于 v 线性，得到线性规划（linear programming, LP）：

$$\begin{aligned} \min_{v} \quad & \sum_{s} w(s) v(s) \\ \text{满足} \quad & v(s) - \gamma \sum_{s'} P(s' \mid s,a) v(s') \ge R(s,a), \quad s \in \mathcal{S},\ a \in \mathcal{A}(s). \end{aligned} \tag{2.7}$$

式 (2.7) 在所有满足 Bellman 不等式的状态函数中，最小化加权价值。这里的 min 寻找最紧的上界，并非把策略的回报改成最小化。每个合法动作都对应一条约束；若事先删除某个动作，其长期后果就不再受到检查，可能改变所求上界。

定理 2.9　价值线性规划的解　任意可行 v 逐状态满足 $v \ge V^*$。若 $w(s) > 0$ 对所有状态成立，则式 (2.7) 的唯一最优解为 V^*。

证明　因为每个动作的备份都不超过 v，这些约束等价于 $v \ge T^* v$。利用单调性反复备份，$v \ge T^* v \ge (T^*)^2 v \ge \cdots$，而压缩性使后者收敛到 V^*，所以 $v \ge V^*$。V^* 自身满足全部约束，因而可行。对任何不同于 V^* 的可行 v，至少一个坐标严格大于 V^*，其他坐标不小于；所有权重严格为正便推出 $\sum_s w(s) v(s) > \sum_s w(s) V^*(s)$。这同时证明最优性和唯一性。 ■

若只比较从 ρ_0 出发的回报，可以取 $w = \rho_0$；所有约束仍然保留，但零权重状态未必得到唯一价值。例如在走廊之外增加不可达的孤立状态 z，其唯一动作是零奖励自循环，约束只要求 $v(z) \ge \gamma v(z)$，也就是 $v(z) \ge 0$。当 $\rho_0(z) = 0$ 时，任何这样的 $v(z)$ 都不影响目标，而真正的 $V^*(z)$ 为 0。因此初始分布下目标已最优，仍不能推出每个坐标都等于全状态最优价值。

2.2.2 占用度量的线性规划

换用访问量作变量时，我们要保证所选分布能由环境中的某份策略产生，不能任意给状态动作分配概率。第 1 章的归一化占用度量为

$$d^{\pi}(s,a)=(1-\gamma)\sum_{t=0}^{\infty}\gamma^{t}\mathbb{P}_{\pi}(s_t=s,a_t=a),\qquad d^{\pi}(s)=\sum_{a}d^{\pi}(s,a).$$

其中 $d^{\pi}(s)$ 汇总折扣时间内落在 s 的概率质量。它一部分来自初始分布，另一部分由此前状态动作转移而来。拆出 $t=0$ 项，再对其余时刻使用全概率公式，便得到这种流守恒关系：

$$\begin{aligned}d^{\pi}(s)&=(1-\gamma)\rho_0(s)+(1-\gamma)\sum_{t=1}^{\infty}\gamma^{t}\sum_{x,a}\mathbb{P}_{\pi}(s_{t-1}=x,a_{t-1}=a)P(s\mid x,a)\\&=(1-\gamma)\rho_0(s)+\gamma\sum_{x,a}P(s\mid x,a)d^{\pi}(x,a).\end{aligned}\tag{2.8}$$

式 (2.8) 要求一个状态分配给各动作的总量，等于初始注入加折扣后的转移流入。图 2.3 把这两项放回三格走廊：注入为 $(1-\gamma)\rho_0$，每条转移流还乘 γ。对所有状态求和，并利用转移概率之和为 1，可得 $\sum_{s,a}d^{\pi}(s,a)=1$。终点吸收后仍占用折扣时间，只是不再产生奖励。

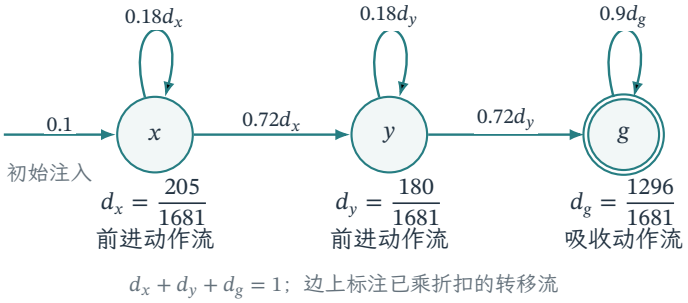


图 2.3 手算走廊中前进策略的归一化折扣流。状态流出分别为 d_x,d_y,d_g；初始注入为 0.1，前进转移流为 $0.72d$，原地流为 $0.18d$，终点吸收流为 $0.9d_g$。等待动作在最优解中的流量为 0，未画出。

这项流约束也会从价值线性规划的对偶中自然出现。取 $w=\rho_0$，把每条价值约束写成“右端减左端不大于 0”，再引入非负乘子 $\lambda(s,a)$。乘子给各约束分配权重，拉格朗日函数把加权约束与原目标相加：

$$\begin{aligned}L(v,\lambda)&=\sum_{s}\rho_0(s)v(s)+\sum_{s,a}\lambda(s,a)[R(s,a)-v(s)]\\&\quad+\gamma\sum_{s,a}\lambda(s,a)\sum_{x}P(x\mid s,a)v(x)\\&=\sum_{s,a}\lambda(s,a)R(s,a)+\sum_{s}v(s)\kappa_{\lambda}(s),\end{aligned}$$

将含同一个 $v(s)$ 的项收集后，其系数为

$$\kappa_\lambda(s) = \rho_0(s) - \sum_a \lambda(s,a) + \gamma \sum_{x,a} P(s \mid x,a)\lambda(x,a).$$

对固定 λ，取 $\inf_v L(v,\lambda)$ 可为原最小化问题给出下界。由于 $v(s)$ 可以取任意实数，若有一个系数 $\kappa_\lambda(s)$ 非零，就能沿相反方向把 L 降到负无穷；只有全部系数为 0 才得到有限下界。这个条件正是注入为 ρ_0 的流方程，因而 λ 对应总质量为 $1/(1-\gamma)$ 的未归一化占用量。对偶在这些可行乘子中最大化下界；代入 $d = (1-\gamma)\lambda$，得到

$$\begin{aligned} \max_{d \ge 0} \quad & \frac{1}{1-\gamma} \sum_{s,a} d(s,a) R(s,a) \\ \text{满足} \quad & \sum_a d(s,a) - \gamma \sum_{x,a} P(s \mid x,a) d(x,a) = (1-\gamma)\rho_0(s), \quad s \in \mathcal{S}. \end{aligned} \tag{2.9}$$

对偶的 max 也可以直接理解为：在满足流守恒的访问量中选取累计期望奖励最大的分布。归一化只改变变量尺度，目标仍是 $J(\pi)$，所以流注入改为 $(1-\gamma)\rho_0$ 后，目标中的 $(1-\gamma)^{-1}$ 必须保留。接着要验证，这些代数上可行的流确实都对应合法策略。

定理 2.10　可行占用量的策略实现　对有限折扣 MDP，任意满足式 (2.9) 约束的 d 都可由平稳随机策略实现。具体地，令 $d(s) = \sum_a d(s,a)$；在 $d(s) > 0$ 处取 $\pi(a \mid s) = d(s,a)/d(s)$，在 $d(s) = 0$ 处任取合法动作分布，则 $d = d^\pi$。

证明　在正占用状态，按比例选择动作直接给出 $d(s,a) = d(s)\pi(a \mid s)$。在零占用状态，各动作量非负且和为 0，只能全部为 0，因此同一等式仍成立，不依赖该处选什么合法分布。代入流方程，并用列向量 $\boldsymbol{d}$ 收集状态占用量，

$$\boldsymbol{d} = (1-\gamma)\boldsymbol{\rho}_0 + \gamma (\boldsymbol{P}^\pi)^\top \boldsymbol{d}.$$

由于 $\boldsymbol{I} - \gamma \boldsymbol{P}^\pi$ 可逆，其转置也可逆，此方程的唯一解为

$$\boldsymbol{d} = (1-\gamma) \sum_{t=0}^{\infty} \gamma^t ((\boldsymbol{P}^\pi)^\top)^t \boldsymbol{\rho}_0.$$

右端正是策略 π 的折扣状态分布。再乘 $\pi(a \mid s)$，得到 $d(s,a) = d^\pi(s,a)$。零占用状态的任意动作选择没有改变这个唯一解。 ■

2.2.3 价值与占用度量的对偶关系

价值线性规划给回报设上界，占用线性规划选取可实现的访问分布；现在需要确认两种求法会不会留下间隙。价值问题可用常数 $R_{\max}/(1-\gamma)$ 作为可行函数，目标又由 V^* 从下方界住。占用问题至少有任意平稳策略的流作为可行点；所有可行 d 非负、总质量为 1，且奖励有界，故目标有界。两者都是有限维、可行且具有有限最优值的线性规划，强对偶定理于是保证最优目标相等。

我们用示例 2.1 检验这种对应。两个非终点处，前进策略的价值都高于等待的一步备份 $-0.04+0.9V(s)$，而前进备份恰好等于该价值，因此前进策略满足最优 Bellman 方程。取 $\rho_0(x)=1$，对应流量满足

$$d_x = 0.1 + 0.18 d_x, \qquad d_y = 0.72 d_x + 0.18 d_y, \qquad d_g = 0.72 d_y + 0.9 d_g.$$

解得

$$(d_x, d_y, d_g) = \frac{1}{1681}(205, 180, 1296).$$

该策略从不等待，等待动作的流量为 0；前进和终点吸收动作分别取得所在状态的全部占用量。将同一组价值与流量代入两个目标，可核对

$$\rho_0^{\top} \boldsymbol{v}^* = V^*(x) = \frac{6718}{8405} = 10\left(-0.04\frac{205}{1681} + 0.792\frac{180}{1681}\right).$$

两个目标确实都等于起点最优价值。终点的占用虽大，却只记录到达后的零奖励时间；它不贡献回报，但不能从归一化流中删除，否则总质量和守恒都将改变。

目标相等还说明正占用动作应当满足哪条价值约束。若某个被使用的动作在 Bellman 上界下仍有严格余量，它就会贡献原始与对偶目标之间的正差。下面把这一关系写成互补松弛条件，也就是非负流量与对应约束余量的乘积为零。

定理 2.11　互补松弛与最优动作　设 v, d 分别为以 ρ_0 加权的价值 LP 和归一化占用 LP 的最优解。若 $d(s,a)>0$，则

$$v(s) = R(s,a) + \gamma \sum_{s'} P(s' \mid s, a) v(s').$$

由 d 按状态归一化恢复的策略在 ρ_0 下最优；仅凭正占用动作的等式，不能断言零占用状态的任意恢复动作也全状态最优。

证明 将流约束乘 $v(s)$ 再求和，原始、对偶目标之差恰为

$$\frac{1}{1-\gamma}\sum_{s,a} d(s,a)\Big[v(s) - R(s,a) - \gamma\sum_{s'} P(s' \mid s,a)v(s')\Big].$$

每项由原始与对偶可行性保证非负，强对偶又使总和为 0。因此，只要 $d(s,a) > 0$，对应方括号必须为 0，这就是互补松弛。定理 2.10 保证恢复策略实现 d，其 J 等于对偶目标，故等于 $\rho_0^\top \boldsymbol{v}^*$。

若某状态占用为 0，乘积为 0 就不再限制该处动作的约束余量。例如在不可达孤立状态增加奖励 -1 的自循环动作，选它不会改变从 ρ_0 出发的目标，但其价值为 $-1/(1-\gamma)$，低于零奖励自循环。要保证全状态最优，可以在所有状态对真正的 V^* 贪心，或改用严格正的初始权重，求出全状态价值后恢复策略。 ■

价值变量便于检查各动作的上界，流量变量则便于累计策略的资源消耗。表 2.4 对照它们与局部备份的检查量。若 $c(s,a)$ 是有界单步成本，只需将占用目标中的奖励换成成本，就能计算该策略的未归一化折扣累计期望：

$$\mathbb{E}_\pi \sum_{t=0}^{\infty} \gamma^t c(s_t,a_t) = \frac{1}{1-\gamma}\sum_{s,a} d^\pi(s,a)c(s,a).$$

所以限制这一成本不超过预算，可以直接增加一条关于 d 的线性约束。这里仅建立计算接口；约束是否可行、是否需要随机化，以及期望成本限制能支持怎样的安全结论，留给第 8 章。

形式	求解关系	适合检查的量
价值迭代	局部 Bellman 备份	全状态残差、贪心损失界
价值 LP	全部动作的上界约束	原始可行性、最小上界
占用 LP	非负流及全局守恒	对偶间隙；累计成本 $\sum dc/(1-\gamma) \le B$

表 2.4 递推与全局优化的不同接口。等价的最优目标不意味着通用 LP 求解器比专用动态规划更快。

2.3 特殊结构下的精确求解

前两节按有限 MDP 的一般形式求解，每个状态都有一个价值未知量，每个合法动作都要参与比较。若动力学、成本或动作之间还有额外关系，我们可能不用逐项保存和比较它们。下面分别考察价值表示、方程形式、策略形状和子问题分解：备份能否保留有限参数形式，换元能否使方程线性化，最优动作能否按状态排序，以及子任务能否分别求解。这些结构作用于不同对象，可以组合，而不是互斥的模型类别。

2.3.1 价值函数族的封闭结构

在连续状态上逐点保存价值无法实现。一种可能的精确简化是用有限参数表示价值，再让每次备份只更新这些参数。但若备份结果离开了原来的函数族，就还需要近似或扩大表示。Bellman **封闭性**（Bellman closure）要求备份之后仍留在所选函数族内，使这种参数更新能够精确重复。

定义 2.12　函数族的 Bellman 封闭性　对给定算子 T 和函数族 $\mathcal{F}$，若 $v \in \mathcal{F}$ 蕴含 $Tv \in \mathcal{F}$，称 $\mathcal{F}$ 在 T 下封闭。有限时域也可使用逐时刻的函数族，要求 $T_t \mathcal{F}_{t+1} \subseteq \mathcal{F}_t$，并要求终端价值属于 $\mathcal{F}_H$。

选择线性参数化并不足以获得封闭性。例如在连续状态 x 上，两个动作分别给出即时奖励 x 和 $-x$，随后立即终止。终端零函数属于线性函数族，一步最优备份却为 $\max(x, -x) = |x|$，不再是 x 的线性函数。下面能精确保留二次形式，是动力学和成本共同提供的结构，不是任意特征表示都能做到的事情。

考虑一个状态可见的控制系统：既要减小偏离目标的程度，又不希望施加过大的控制。**线性二次调节器**（linear quadratic regulator, LQR）用线性动力学和二次成本表达这两项要求。这里不再使用有限网格，而令状态 $\boldsymbol{x}_t \in \mathbb{R}^{n_x}$、动作 $\boldsymbol{u}_t \in \mathbb{R}^{n_u}$，动作无额外约束；目标也改为有限时域、无折扣的成本最小化。记最小剩余成本为 C_t，若将成本取负作为奖励，对应奖励价值就是 $-C_t$。动力学为

$$\boldsymbol{x}_{t+1} = \boldsymbol{A}\boldsymbol{x}_t + \boldsymbol{B}\boldsymbol{u}_t + \boldsymbol{w}_t, \quad \boldsymbol{A} \in \mathbb{R}^{n_x \times n_x},\ \boldsymbol{B} \in \mathbb{R}^{n_x \times n_u}.$$

加性噪声 $\boldsymbol{w}_t$ 相互独立，并独立于此前状态与动作，均值为 0、协方差 $\boldsymbol{\Sigma}_t$ 有限。为了在允许的控制序列中比较偏离与用力，我们最小化总期望成本

$$\mathbb{E}\left[\sum_{t=0}^{H-1} (\boldsymbol{x}_t^\top \boldsymbol{Q}\boldsymbol{x}_t + \boldsymbol{u}_t^\top \boldsymbol{R}\boldsymbol{u}_t) + \boldsymbol{x}_H^\top \boldsymbol{Q}_f \boldsymbol{x}_H\right], \tag{2.10}$$

其中对称矩阵 $\boldsymbol{Q}, \boldsymbol{Q}_f \succeq 0$ 分别计入逐步状态成本和终端成本，$\boldsymbol{R} \succ 0$ 计入控制成本；这里 $\boldsymbol{Q}$ 不是动作价值 Q。反向递推应从指定的终端成本 $C_H(\boldsymbol{x}) = \boldsymbol{x}^\top \boldsymbol{Q}_f \boldsymbol{x}$ 开始，而不默认沿用网格的零终端值。正定的控制成本还将保证每步配方有唯一的最小化动作。

终端值已经是二次函数。为检查一次备份能否保留它，假设 $C_{t+1}(\boldsymbol{x}) = \boldsymbol{x}^\top \boldsymbol{S}_{t+1} \boldsymbol{x} + c_{t+1}$，其中 $\boldsymbol{S}_{t+1} \succeq 0$，再令 $\boldsymbol{m} = \boldsymbol{A}\boldsymbol{x} + \boldsymbol{B}\boldsymbol{u}$。先计算随机后继的成本：噪声零均值使与 $\boldsymbol{m}$ 的交叉项期望为零，二次噪声项由协方差决定，故

$$\mathbb{E}[(\boldsymbol{m} + \boldsymbol{w}_t)^\top \boldsymbol{S}_{t+1} (\boldsymbol{m} + \boldsymbol{w}_t)] = \boldsymbol{m}^\top \boldsymbol{S}_{t+1} \boldsymbol{m} + \operatorname{tr}(\boldsymbol{S}_{t+1} \boldsymbol{\Sigma}_t).$$

把这项后继期望与当前状态成本、控制成本相加，Bellman 备份在 $\boldsymbol{u} \in \mathbb{R}^{n_u}$ 上最小化

$$\begin{aligned}&\boldsymbol{x}^{\top}(\boldsymbol{Q}+\boldsymbol{A}^{\top}\boldsymbol{S}_{t+1}\boldsymbol{A})\boldsymbol{x}+2\boldsymbol{u}^{\top}\boldsymbol{B}^{\top}\boldsymbol{S}_{t+1}\boldsymbol{A}\boldsymbol{x}\\&\quad+\boldsymbol{u}^{\top}(\boldsymbol{R}+\boldsymbol{B}^{\top}\boldsymbol{S}_{t+1}\boldsymbol{B})\boldsymbol{u}+c_{t+1}+\operatorname{tr}(\boldsymbol{S}_{t+1}\boldsymbol{\Sigma}_t).\end{aligned}$$

这个目标关于控制 $\boldsymbol{u}$ 是二次的。令正定矩阵 $\boldsymbol{M}_t = \boldsymbol{R}+\boldsymbol{B}^{\top}\boldsymbol{S}_{t+1}\boldsymbol{B}$，以及 $\boldsymbol{K}_t = \boldsymbol{M}_t^{-1}\boldsymbol{B}^{\top}\boldsymbol{S}_{t+1}\boldsymbol{A}$，可以通过配方同时求出最小成本和达到它的控制：

$$\begin{aligned}\boldsymbol{u}^{\top}\boldsymbol{M}_t\boldsymbol{u}+2\boldsymbol{u}^{\top}\boldsymbol{B}^{\top}\boldsymbol{S}_{t+1}\boldsymbol{A}\boldsymbol{x} &= (\boldsymbol{u}+\boldsymbol{K}_t\boldsymbol{x})^{\top}\boldsymbol{M}_t(\boldsymbol{u}+\boldsymbol{K}_t\boldsymbol{x})\\&\quad-\boldsymbol{x}^{\top}\boldsymbol{K}_t^{\top}\boldsymbol{M}_t\boldsymbol{K}_t\boldsymbol{x}.\end{aligned}$$

正定性使配方后的第一项非负，且只在 $\boldsymbol{u}_t^{*} = -\boldsymbol{K}_t\boldsymbol{x}_t$ 处为零。这个动作是当前状态的线性反馈；将它代回目标，剩余项仍为二次状态成本加常数。Riccati **递推**（Riccati recursion）就是从终端向前更新二次成本矩阵和反馈增益的关系：

$$\begin{aligned}\boldsymbol{K}_t &= (\boldsymbol{R}+\boldsymbol{B}^{\top}\boldsymbol{S}_{t+1}\boldsymbol{B})^{-1}\boldsymbol{B}^{\top}\boldsymbol{S}_{t+1}\boldsymbol{A},\\ \boldsymbol{S}_t &= \boldsymbol{Q}+\boldsymbol{A}^{\top}\boldsymbol{S}_{t+1}\boldsymbol{A}-\boldsymbol{A}^{\top}\boldsymbol{S}_{t+1}\boldsymbol{B}(\boldsymbol{R}+\boldsymbol{B}^{\top}\boldsymbol{S}_{t+1}\boldsymbol{B})^{-1}\boldsymbol{B}^{\top}\boldsymbol{S}_{t+1}\boldsymbol{A},\\ c_t &= c_{t+1}+\operatorname{tr}(\boldsymbol{S}_{t+1}\boldsymbol{\Sigma}_t),\\ \boldsymbol{S}_H &= \boldsymbol{Q}_f, \qquad c_H = 0.\end{aligned} \tag{2.11}$$

无噪声部分是非负成本的最小值，因此 $\boldsymbol{S}_t \succeq 0$，下一步配方所需的条件也保留下来。噪声的协方差只进入常数 c_t，不改变反馈增益 $\boldsymbol{K}_t$；这依赖完全可见状态和独立加性噪声。若动作改变噪声分布，或控制前还要估计隐藏状态，就不能原样继承这项结论。确定性有限时域推导及标准递推可参见 Boyd 的课程讲义[4]。

示例 2.13　标量 Riccati 递推　取教学参数 $A = B = Q = R = Q_f = 1$、$H = 2$。从 $S_2 = 1$ 得到 $K_1 = 1/2$、$S_1 = 2 - 1/2 = 3/2$，再得 $K_0 = (3/2)/(5/2) = 3/5$、$S_0 = 5/2 - 9/10 = 8/5$。无噪声且 $x_0 = 1$ 时，$u_0 = -3/5$、$x_1 = 2/5$、$u_1 = -1/5$、$x_2 = 1/5$。代入成本，

$$1 + \frac{9}{25} + \frac{4}{25} + \frac{1}{25} + \frac{1}{25} = \frac{8}{5} = C_0(1).$$

若两步噪声方差都改为 0.04，反馈增益不变，$c_1 = 0.04$、$c_0 = 0.04 + 1.5 \times 0.04 = 0.10$，故最优期望成本为 1.70；这不是同一条确定轨迹的成本。

图 2.4 对应了刚才的归纳：虽然状态取值无穷，一次精确备份只更新矩阵和常数，执行时再用矩阵乘法计算反馈。一般动作约束可能使配方所得控制不可行，非线性动力学也可能使后继成本不再二次，因而都要重新检查封闭性，不能继续断言价值在整个状态空间上为二次函数。

[4] S. Boyd, *Linear Quadratic Regulator: Discrete-Time Finite Horizon*, EE363, Lecture 1, Winter 2008–09, Stanford University, 2009, URL: https://stanford.edu/class/ee363/lectures/dlqr.pdf (visited on 10/04/2026)

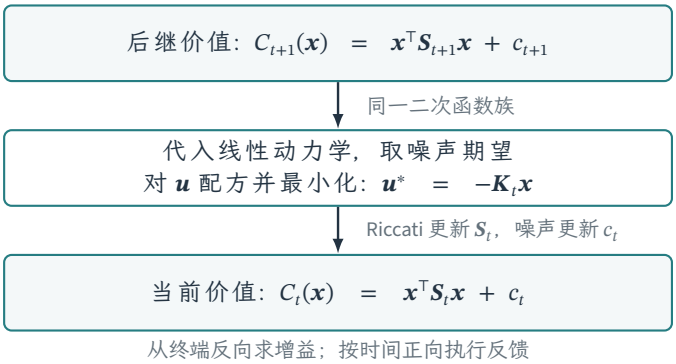


图 2.4 有限时域 LQR 的封闭关系。给定线性动力学、二次成本与独立零均值加性噪声，最小化一步成本后仍得到二次价值加常数；增益由反向递推得到，控制按正向时间执行。

有限时域封闭还不能保证时域趋于无穷后成本有限。对无噪声、无折扣的无限总成本，标准结果另要求 $(\boldsymbol{A}, \boldsymbol{B})$ 可稳定、$(\boldsymbol{Q}^{1/2}, \boldsymbol{A})$ 可检测，并保留 $\boldsymbol{Q} \succeq 0$、$\boldsymbol{R} \succ 0$。可稳定意味着存在反馈，使闭环 $\boldsymbol{A} - \boldsymbol{B}\boldsymbol{K}$ 的特征值落在单位圆内；可检测意味着成本无法观测到的状态模式不会不稳定增长。在这些条件下，零终端成本的递推随时域延长，收敛到唯一半正定稳定化解 $\boldsymbol{S}$。它满足将式 (2.11) 中的 $\boldsymbol{S}_t, \boldsymbol{S}_{t+1}$ 都替换成 $\boldsymbol{S}$ 所得的代数 Riccati 方程。

证明先用非负成本说明更长时域的价值单调增加，再用可稳定反馈提供有限二次上界，从而得到矩阵序列的极限。递推的连续性给出代数方程，可检测性则用于排除不稳定闭环模式。因此，一个满足代数方程的解未必就是所需的稳定化解。持续非零噪声通常还会使无折扣无限总成本发散，需要改用平均成本等准则；有限时域的常数项可以求出，并不代表无限累加仍有限。

2.3.2 价值方程的可线性化结构

LQR 减少了价值表示所需的未知量，但求反馈时仍要进行二次最小化和矩阵求逆。另一种结构直接限制可选控制及其成本，使价值方程能够通过换元线性化，而不要求价值属于低维函数族。考虑把控制写成下一状态的概率分布：控制越偏离系统自然转移，费用越高。KL 控制用 KL 散度计量这种分布偏离，允许优化的是受支持约束的转移分布，不是一般 MDP 中任意给定的一组动作。

定义 2.14 有限时域 KL 控制 给定有限状态集、被动转移 $P_0(s' \mid s)$、取有限实数值的状态成本 $c_t(s)$ 和终端成本 $g(s)$，以及 $\lambda > 0$。在状态 s 可选择概率分布 $u(\cdot \mid s)$，要求 $P_0(s' \mid s) = 0$ 时 $u(s' \mid s) = 0$。单步期望成本为

$$c_t(s) + \lambda D_{\mathrm{KL}}(u(\cdot \mid s) \| P_0(\cdot \mid s)).$$

> 本节以 V_t^{c} 表示最小剩余成本，取 $V_H^{\mathrm{c}} = g$，不折扣；奖励最大化的对应价值为 $-V_t^{\mathrm{c}}$。

被动转移 P_0 表示不施加这种分布控制时的自然规律。支持约束使控制只能重新分配自然规律已有的可能后继，不能以有限费用创造原本概率为零的转移。对支持内概率采用 $0 \log 0 = 0$ 约定；严格正的 λ 保证偏离确实增加成本，控制必须权衡这项费用与未来成本。

给定下一时刻的最小成本 V_{t+1}^{c}，当前要在允许的概率分布 u 中，最小化 KL 费用加后继成本期望。我们先用被动概率和后继成本构造一个候选：令 $Z_t(s) = \sum_{s'} P_0(s' \mid s) \exp(-V_{t+1}^{\mathrm{c}}(s')/\lambda) > 0$ 作为归一化系数，并取

$$u_t^*(s' \mid s) = \frac{P_0(s' \mid s) \exp(-V_{t+1}^{\mathrm{c}}(s')/\lambda)}{Z_t(s)}.$$

候选 u_t^* 满足支持约束。把其对数代入 KL 散度，可以将任意允许分布 u 的待优化成本写成

$$\begin{aligned} &\lambda D_{\mathrm{KL}}(u \| P_0) + \sum_{s'} u(s' \mid s) V_{t+1}^{\mathrm{c}}(s') \\ &\quad = \lambda D_{\mathrm{KL}}(u \| u_t^*) - \lambda \log Z_t(s). \end{aligned} \tag{2.12}$$

右侧第二项不随 u 改变，第一项非负且在 $u = u_t^*$ 时为 0。因此 u_t^* 在整个允许分布集合上达到最小值，不只满足一阶必要条件。加回当前状态成本，得到

$$V_t^{\mathrm{c}}(s) = c_t(s) - \lambda \log Z_t(s).$$

这个最小值替代了原来的分布优化。u_t^* 给低成本后继更大的指数权重，再由 P_0 和 Z_t 保持支持与归一化；指数中的负号来自成本越小越优，不能原样解释为奖励最大化中的偏好。

上式仍含对数，但我们可以改求成本的指数变换，而不直接求成本。令 $z_t(s) = \exp(-V_t^{\mathrm{c}}(s)/\lambda)$，对等式两侧取相应指数，便有

$$z_t(s) = \exp(-c_t(s)/\lambda) \sum_{s'} P_0(s' \mid s) z_{t+1}(s'), \qquad z_H(s) = \exp(-g(s)/\lambda). \tag{2.13}$$

后继未知量 z_{t+1} 现在只出现在加权和中，所以这是线性反向递推。由终端值算出 z 后，再用 $u_t^*(s' \mid s) = P_0(s' \mid s) z_{t+1}(s') / \sum_x P_0(x \mid s) z_{t+1}(x)$ 恢复最优转移，若需成本则用 $V_t^{\mathrm{c}} = -\lambda \log z_t$ 还原。控制限制、指数变换和不同时间目标的关系可参见 Todorov 的原始工作[5]。

用一个只剩一步的教学模型检查这种权衡。被动转移以相等概率到达两处，终端成本分别为 0 和 $\lambda \log 3$，当前状态成本为 0。两处 z_H 为 1 和 $1/3$，所以 $Z = 2/3$，最优受控概率为 $(3/4, 1/4)$，最小成本为 $\lambda \log(3/2)$。

若全部转向第一处，终端成本虽为 0，偏离被动分布的费用却为 $\lambda \log 2$，总成本更高。因此最优分布仍给第二个后继保留概率。

线性化依赖刚才的控制费用和时间目标。表 2.5 对照有限时域、终止型和平均成本中的边界条件。一般折扣成本方程含 $\gamma V(s')$，同样换元得到 $z(s) = e^{-c(s)/\lambda} \sum_{s'} P_0(s' \mid s) z(s')^{\gamma}$，通常仍然非线性。即使方程已经线性，也未必减少未知量个数：表格表示仍需保存每个状态的 $z(s)$。

目标	换元后的关系	所需边界或附加条件
有限时域	$\boldsymbol{z}_t = \boldsymbol{G}_t \boldsymbol{P}_0 \boldsymbol{z}_{t+1}$	$\boldsymbol{G}_t = \mathrm{diag}(e^{-c_t/\lambda})$，终端 $\boldsymbol{z}_H = e^{-\boldsymbol{g}/\lambda}$
终止型总成本	$\boldsymbol{z}_N = \boldsymbol{G}_N(\boldsymbol{P}_{NN}\boldsymbol{z}_N + \boldsymbol{P}_{NB}\boldsymbol{z}_B)$	固定终点集 B 的边值；如 $\boldsymbol{G}_N\boldsymbol{P}_{NN}$ 的谱半径小于 1，线性方程唯一可解
平均成本	$e^{-\bar{c}/\lambda}\boldsymbol{z} = \boldsymbol{G}\boldsymbol{P}_0\boldsymbol{z}$	有限不可约被动链、有限成本给正的 Perron 特征向量；只确定尺度，非周期性影响幂迭代
一般折扣成本	$\boldsymbol{z} = \boldsymbol{G}\boldsymbol{P}_0\boldsymbol{z}^{\gamma}$	幂按坐标作用；不再是线性方程

表 2.5 KL 控制的三类线性形式及折扣边界。终止型的 N 表示非终点集合，不是时间；平均成本的 $\bar{c}$ 是每步最优平均成本。

表中的平均成本关系来自 $\bar{c} + V^{\mathrm{c}}(s) = c(s) - \lambda \log \sum_{s'} P_0(s' \mid s) e^{-V^{\mathrm{c}}(s')/\lambda}$ 的指数变换。此时 V^{c} 是扣除平均增长后的差分成本，换元所得 z 只确定到尺度。不可约非负矩阵的 Perron 理论保证所需正特征向量；沿轨迹累加成本等式，再除以时长，有界差分成本的首尾项消失，从而验证平均成本最优性。这条证明使用特征值与平均成本关系，不是折扣压缩论证。

2.3.3 最优策略的单调与阈值结构

库存状态可以按数量排序，动作也可以按大小排序。若每个库存状态都单独比较全部动作，会忽略最优选择可能具有的顺序关系；不过必须先说清动作表示什么。库存增加时，“订货量”可能下降，“订货后的总库存”却可能上升。**单调策略**指状态按一个方向增大时，所选动作也始终沿固定方向变化；对二元动作，这种规则常由一个切换点确定，称为**阈值策略**。库存中的**基库存策略**把订后库存设为 $\max\{x, S_t\}$，订货量为 $(S_t - x)_+$。这些形状减少了要描述的选择，但阈值或基库存水平 S_t 仍须从模型和目标求出。

为判断这种顺序关系是否成立，我们比较大动作相对小动作的成本差。若状态增加使大动作相对更便宜，就可能支持较大的最优选择。将当前成本与后继成本期望合成一步目标 $f(s,a)$，称其具有**递减差分**，若对 $s_2 \geq s_1$、$a_2 \geq a_1$，

$$f(s_2,a_2) - f(s_2,a_1) \leq f(s_1,a_2) - f(s_1,a_1). \tag{2.14}$$

这个条件比较的是两动作成本之差，而不是要求每个动作的绝对成本下降。以下定理在共同的有限全序动作集中最小化 f；遇到并列最小值时，统一选最大的动作，才能得到所述单调选择。更一般的格上比较静态结果见 Topkis[6]。

[6] D. M. Topkis, *Minimizing a Submodular Function on a Lattice* In Operations Research, 1978, vol. 26, no. 2, pp. 305–321

定理 2.15 递减差分给出单调最优动作 状态有序、各状态共享同一个有限全序动作集，目标为成本最小化。若 f 满足式 (2.14)，则选取最大的最小化动作 $a^*(s) = \max \arg\min_a f(s,a)$ 得到随 s 单调不减的策略。

证明 取 $s_2 \geq s_1$，记 $a_1 = a^*(s_1)$、$a_2 = a^*(s_2)$。反设 $a_2 < a_1$。最优性给出 $f(s_1,a_1) - f(s_1,a_2) \leq 0$ 与 $f(s_2,a_1) - f(s_2,a_2) \geq 0$。递减差分又给出

$$0 \leq f(s_2,a_1) - f(s_2,a_2) \leq f(s_1,a_1) - f(s_1,a_2) \leq 0.$$

所有不等式只能取等号，故 a_1 也是 s_2 处的最小化动作。但 $a_1 > a_2$，与 a_2 是最大的最小化动作矛盾。因此 $a_2 \geq a_1$。 ■

将定理用于多步决策，还必须证明后继成本加入后，差分条件仍保持。考虑一个可逐步验证的排队模型：状态 $x \in \{0,\dots,B\}$ 表示有容量上限的队长，动作 $a = 0$ 保留队列，$a = 1$ 立即清空。保留支付非负且随 x 不减的等待成本 $h(x)$，清空支付固定成本 $K > 0$。随后产生与状态动作独立、分布已知的非负到达 W_t，容量外到达丢弃且不另收费。两动作的后继分别为 $\min(x + W_t, B)$ 和 $\min(W_t, B)$。取有限时域、无折扣、终端成本 0。

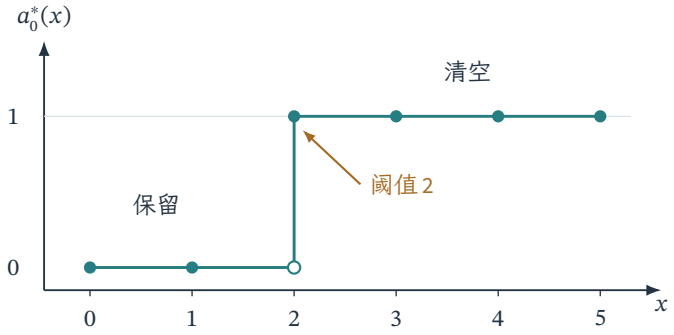
若 C_{t+1} 单调不减，则

$$f_t(x,0) = h(x) + \mathbb{E}C_{t+1}(\min(x + W_t, B)),$$
$$f_t(x,1) = K + \mathbb{E}C_{t+1}(\min(W_t, B)).$$

保留目标随 x 不减，清空目标不随 x 变化，取两者最小值得到的 C_t 仍随 x 不减。从 $C_H = 0$ 反向归纳，这项性质逐步保持。与此同时，清空相对保留的成本差 $f_t(x,1) - f_t(x,0)$ 随 x 不增，满足递减差分。因此在上述模型中，可以按阈值选择清空。若清空费用依赖队长、丢包另有复杂成本，或到达规律随服务动作变化，就必须重新验证每一步目标，不能只凭“排队模型”沿用阈值结论。

为求出阈值而不只说明其存在，取教学参数 $B = 5$、$h(x) = x$、$K = 2.5$、$W_t = 1$、$H = 2$。最后一步最小成本为 $C_1(x) = \min(x, 2.5)$。在 $t = 0$，清空目标恒为 $2.5 + C_1(1) = 3.5$，保留目标为 $x + C_1(\min(x+1, 5))$；后者在 $x = 0, 1, 2$ 分别为 1、3、4.5，且继续随 x 不减。因此从 $x = 2$ 起清空更便宜，阈值为 2，见图 2.5。

回到库存时，订后库存 y 受 $y \geq x$ 约束，各状态的允许动作不同，不能直接套用共同动作集的定理。在经典模型中，订货立即到达，需求独立，缺货可以结转；没有固定订货费，单位订货费线性，持有和缺货成本凸。若



$B = 5$, $K = 2.5$, $W = 1$, $H = 2$；仅整数点是状态

图 2.5　上述两步排队教学模型在 $t = 0$ 的最优动作。横轴是整数队长，纵轴 0 表示保留、1 表示清空；连接线只帮助阅读阶梯形状，不表示连续状态模型。阈值 2 由列出的 Bellman 目标计算。

终端成本凸且每步目标能取到最小值，动态规划保持所需凸性。令 c 为单位订货费，一步目标可写成 $-cx + G_t(y)$，其中 G_t 凸；在 $y \geq x$ 中最小化便得到 $y^* = \max(x, S_t)$，S_t 为 G_t 的一个最小化点。于是订后库存随 x 不减，订货量随 x 不增；加入固定订货费等条件后，策略形状可能改变。

2.3.4 整体价值与策略的可分离结构

若两个设备各自转移、奖励可加，我们希望分别求出局部价值，而不枚举所有联合状态。能否这样做还取决于动作约束：两台设备若共享一个操作者，每步只能操作一台，就不能同时选取各自最优的动作。下面先说明直接分解需要哪些条件，再检查共享资源改变了哪一步推导。

定理 2.16　独立子过程的可分离性　设 $s = (s_1, \dots, s_m)$，动作集合是 $\mathcal{A}(s) = \prod_i \mathcal{A}_i(s_i)$，

$$P(s' \mid s, a) = \prod_i P_i(s_i' \mid s_i, a_i), \qquad R(s, a) = \sum_i R_i(s_i, a_i).$$

在有限状态动作的折扣问题中，$V^*(s) = \sum_i V_i^*(s_i)$，且各子过程的最优动作可分别选择。有限时域中，若终端价值也可加，同一结论按时刻成立。

证明　对任意可加函数 $v(s) = \sum_i v_i(s_i)$，利用转移的乘积形式并对其他坐标求和，

$$\sum_{s'} P(s' \mid s, a) v(s') = \sum_i \sum_{s_i'} P_i(s_i' \mid s_i, a_i) v_i(s_i').$$

因为每个 a_i 可以独立地在 $\mathcal{A}_i(s_i)$ 中选择，

$$(T^*v)(s) = \max_{a_1,\dots,a_m} \sum_i \left[R_i(s_i,a_i) + \gamma \sum_{s_i'} P_i(s_i' \mid s_i,a_i) v_i(s_i') \right] = \sum_i (T_i^* v_i)(s_i).$$

最后一个等式的两个方向分别来自“任意动作的和不超过各自最大值之和”和“同时选择每个最大化动作便达到该和”。有限时域由可加终端值反向归纳，且逐层的独立最大化恢复策略。折扣情形取各子过程固定点 $v_i = V_i^*$，其和成为联合 T^* 的固定点；唯一性给出联合最优价值，独立最大化动作构成联合最优策略。 ■

图 2.6 上部的两个子网格各自接收动作，允许同时执行局部最大化选择；若改为每步最多激活一个，证明中把联合最大值拆成各自最大值之和的等式就不再成立。一个最小反例是两个单状态设备：激活每步得 1，空闲得 0，状态恒定。在笛卡尔积动作下可同时激活，联合价值为 $2/(1-\gamma)$；互斥激活后只能得到 $1/(1-\gamma)$。因此独立转移不足以保证局部最优价值相加。

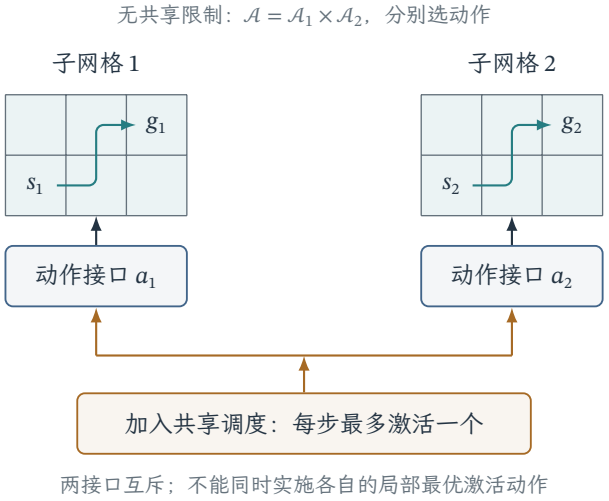


图 2.6　可分解的动力学不等于可分解的决策。上部两个子网格分别接收 a_1, a_2；下部共享调度选择只能激活一个接口，使联合动作集不再是原局部动作集的笛卡尔积。

共享激活虽破坏直接相加，有时仍能利用更强结构安排选择。**经典冻结型 Markov 老虎机**（rested Markov bandit）把每个独立设备看作一个臂：只有当前激活的臂转移并产生奖励，其余臂状态不变、奖励为 0；每步恰好激活一个，且无切换成本。在有限状态、已知转移、有界非负奖励、共同 $0 < \gamma < 1$ 及无限时域目标下，Gittins 指数定理允许给各臂单独计算一个数，再每步激活当前指数最大的臂。

这个数要比较连续激活一个臂的收益与所占用的折扣时间。对臂 i 当前状态 x，我们允许根据已见局部历史决定何时停止，至少激活一次；在这些停止规则中，取期望累计奖励与期望累计折扣时间之比的上确界：

$$\nu_i(x) = \sup_{\tau \geq 1} \frac{\mathbb{E}_x \sum_{t=0}^{\tau-1} \gamma^t R_i(X_t)}{\mathbb{E}_x \sum_{t=0}^{\tau-1} \gamma^t}, \tag{2.15}$$

其中 X_t 是持续激活该臂时的局部状态过程，τ 是由该臂已见历史决定的停止时刻，$\tau \geq 1$ 保证分母为正。比值按折扣时间衡量收益，用上确界容纳所有允许的停止规则，不要求某个有限停止时刻必定取到它。也可以把候选指数 λ 当作每次激活的机会成本，考察净收益 $\sup_{\tau \geq 1} \mathbb{E}_x \sum_{t<\tau} \gamma^t (R_i(X_t) - \lambda)$，净收益由正转为非正的临界 λ 给出上述指数。全局最优性并非来自价值直接相加，而是利用未激活臂的冻结性，交换比较竞争臂的激活片段，证明按指数排序不损失回报。完整指数理论与局部计算方法见 Gittins 的原文[7]。

[7] J. C. Gittins, *Bandit Processes and Dynamic Allocation Indices* In Journal of the Royal Statistical Society. Series B (Methodological), 1979, vol. 41, no. 2, pp. 148–177

若未激活的臂也会演化，即 restless 情形，等待期间的状态会改变，刚才利用冻结性交换片段的依据就不再适用；任意有限截止日期或切换成本也不在此定理范围内。各臂内部仍可能具有封闭、可线性化或单调结构，但简化局部计算并不自动解决共享激活造成的全局耦合。

2.4 面向当前状态的有限预算下的近似规划

前面的精确求法为整个状态空间计算价值或反馈。若导航系统必须很快给出当前位置的下一步动作，却没有预算先算完所有状态，我们可以只展开从这里出发的可能后果。局部搜索把时间集中到当前决策，但没有保存完整解；到达新状态后，往往还要重新搜索。

2.4.1 有限预算下的近似规划问题

设机器人已经位于某个网格状态，当前规划只需返回一个动作，也可以附带各候选动作的价值估计。我们既要考察首动作的长期后果，也要检查它是否在行动截止时间前算出、用了多少模型查询及搜索内存。全状态方法可能先花较长时间预计算，执行时却只查一次表；局部方法可能总查询较少，单次搜索仍超时。因此比较两者时，要分别记录预计算预算和行动时的预算。

图 2.7 展示一次局部搜索的四种安排：限制向前看的步数，限制每层展开的分支，在停止展开处补上未来价值，再根据已有结果选择下一次模拟路径。它们控制同一棵树的不同部分，可以共同使用；后面分别分析各自省去了什么计算，又留下什么误差。

展开方式仍由模型接口决定。精确模型若给出非零概率后继，就可以逐个展开并加权求和；只有生成模型时，一次查询只产生一个随机后继，要

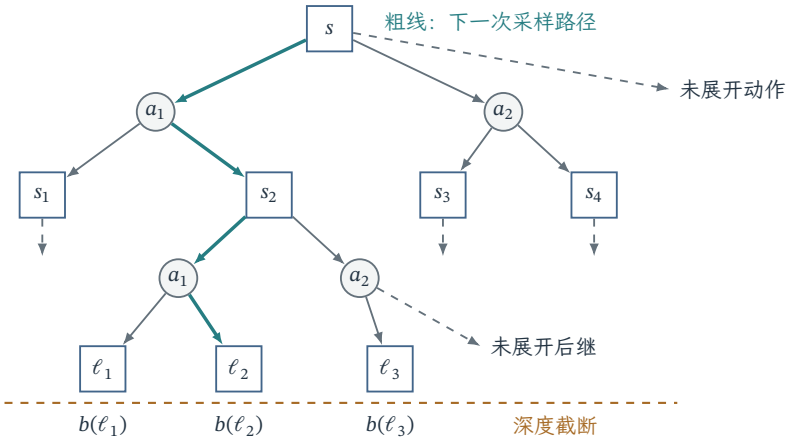


图 2.7 局部搜索中的四种预算安排。方框是状态处的动作选择，圆点是选定动作后的随机后继选择；虚线边表示未展开的分支，底部虚线表示深度截断，叶子处的 b 为剩余价值估计。加粗路径表示下一次模拟的一个可能样本路径，不表示确定的环境转移。

靠重复查询估计期望。两种接口都要区分可选择的动作与不可选择的随机结果：规划器决定查询哪个动作，却不能挑出最有利后继当作必然结果。即使采样规律准确，有限模拟仍有统计误差。

2.4.2 未来步数受限的搜索空间构造

无限展开不可行时，我们先只计算当前状态 s 起的 H 步奖励，再用边界函数 b 补记第 H 步以后尚未展开的价值。允许策略 σ 在这 H 步内根据已经到达的状态选合法动作，以期望折扣回报越大越优，在这些策略中取上确界：

$$U_H^b(s) = \sup_{\sigma} \mathbb{E}_{\sigma}\left[\sum_{t=0}^{H-1} \gamma^t r_t + \gamma^H b(s_H) \,\middle|\, s_0 = s\right]. \tag{2.16}$$

这里 $b(s_H)$ 是到达搜索边界后剩余回报的估计，乘 γ^H 是因为它从第 H 步起算。σ 能够回应实际后继，所以优化的是反馈决策树，而非一条预先固定的动作串。在有限状态动作条件下，可以从 $U_0^b = b$ 逐层计算 $U_h^b = T^* U_{h-1}^b$。取 $b = 0$ 只是忽略搜索范围外的回报，并没有把真实任务改成第 H 步终止。

滚动时域规划（receding-horizon planning）求出这棵有限决策树后，只执行根动作；观察实际新状态，再从那里规划同样长的 H 步。这样能够根据实际滑移调整后续选择，但重新规划本身没有补足边界之外的价值。要判断有限前瞻有多准确，仍须控制边界估值误差及其向根部的传播。

定理 2.17　有限前瞻的终端误差　对有界终端函数 $b, \tilde{b}$，

$$\|U_H^b - U_H^{\tilde{b}}\|_\infty \le \gamma^H \|b - \tilde{b}\|_\infty .$$

特别地，若 $\|b - V^*\|_\infty \le \varepsilon$，则 $\|U_H^b - V^*\|_\infty \le \gamma^H \varepsilon$；零终端值满足 $\|U_H^0 - V^*\|_\infty \le \gamma^H R_{\max}/(1-\gamma)$。固定同一策略序列、比较其两个终端估值时，同样成立。

证明　对任意同一策略序列，两个 H 步目标的前 H 步奖励相消，差只剩 $\gamma^H \mathbb{E}[b(s_H) - \tilde{b}(s_H)]$，绝对值不超过 $\gamma^H \|b - \tilde{b}\|_\infty$。对两个目标分别取上确界，利用 $|\sup f - \sup g| \le \sup |f - g|$，该界仍成立。也可逐层使用期望的非扩张性和最大化的非扩张性，每层再乘 γ，得到同一结果。

取 $\tilde{b} = V^*$ 时，$T^* V^* = V^*$ 保证 $U_H^{V^*} = V^*$，即得第二条。又因 $\|V^*\|_\infty \le R_{\max}/(1-\gamma)$，令 $b = 0$ 得到零边值界。它也等于直接控制尾和 $\sum_{t=H}^{\infty} \gamma^t |r_t| \le \gamma^H R_{\max}/(1-\gamma)$ 所得的界。 ■

终端误差界控制的是 H 步前瞻值，还不是滚动执行策略的价值。若每次使用相同 H、边界函数 b 及固定并列规则，精确根动作便定义一个平稳策略。计算根动作时，当前奖励后面接的是剩余 $H-1$ 步的 U_{H-1}^b，所以该策略对 U_{H-1}^b 贪心，不是对 U_H^b 贪心。由定理 2.8，当 $H \ge 1$ 且 $\|b - V^*\|_\infty \le \varepsilon$ 时，其长期损失至多 $2\gamma^H \varepsilon/(1-\gamma)$。这才把前瞻精度与反复执行的性能联系起来。

示例 2.18　同一障碍下的短前瞻　为隔离时域的影响，采用基准网格的坐标、障碍和终点，但将起点改为 $(1, 2)$，取消滑移，使合法动作确定执行；奖励和 $\gamma = 0.9$ 不变，所有搜索使用 $b = 0$。从起点向上绕过障碍，最短 4 步到终点；向下进入底部通道，至少 6 步到终点。

长度 L 的确定到达路径的回报为 $-0.04 \sum_{t=0}^{L-2} 0.9^t + 0.9^{L-1}$。当 $H = 2$ 时，上、下动作的最优截断回报都为 -0.076，按“下优先”的并列规则会选下。当 $H = 4$ 时，向上的分支已经看到终点，回报为 0.6206；向下的分支仍只有四次步成本，回报为 -0.13756。完整 6 步底部路线的回报为 0.426686，也低于上方路线。

图 2.8 让我们看到，短前瞻的并列来自两条分支都还没有计入终点收益。重复短规划未必解决这个问题：始终取 $H = 1$ 和“下、上、右、左”的并列次序，起点会向下，底部左格又向上，形成往返。若某个早期动作不可逆，后来即使延长搜索，也不能撤销已经付出的损失。

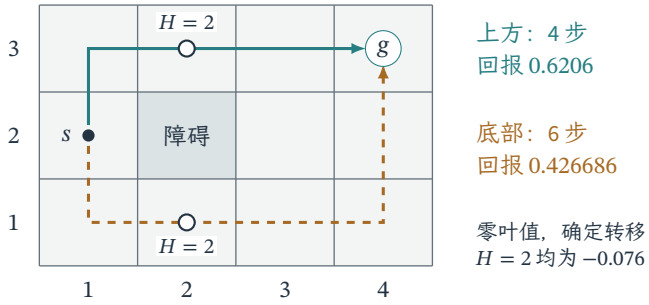


图 2.8 确定性教学变体中的两条绕行路线。实线为 4 步上方路线，虚线为 6 步底部路线；标记 $H = 2$ 说明两个首动作在零叶值下都尚未看到终点。图中条件仅用于示例 2.18，不替代基准随机网格。

2.4.3 未来分支受限的搜索空间构造

固定深度 H 以后，树仍可能太宽：每个状态有多个候选动作，每个动作又有多个随机后继。限制动作数是在删去允许的选择，可能遗漏最优动作；限制采样后继数则是在近似保留动作的期望后果。两者改变的对象不同，不能把只抽一个后继说成环境已经变为确定的。

稀疏采样（sparse sampling）保留有限动作的枚举，但只为每个动作从生成模型独立抽取 m 个后继，再递归计算这些样本上的未来价值。这样用样本均值近似随机后果的期望，用最大值选择合法动作，而不枚举全体状态。取零叶值时，递归为

$$\begin{aligned} \widehat{U}_0(s) &= 0, \\ \widehat{Q}_h(s,a) &= \frac{1}{m}\sum_{j=1}^{m}\left[r_j + \gamma \widehat{U}_{h-1}^{(j)}(s'_j)\right], \\ \widehat{U}_h(s) &= \max_{a \in \mathcal{A}(s)} \widehat{Q}_h(s,a). \end{aligned} \tag{2.17}$$

其中 j 编号的是同一 (s,a) 下的样本 (r_j, s'_j)，不是轨迹时刻；$\widehat{U}_{h-1}^{(j)}$ 来自第 j 棵递归子树，而非同一张表的第 j 轮更新。每棵子树继续使用新样本。若每处动作数至多为 A，一层为 A 个动作各付出 m 次查询，并为每个样本建立子树，因此 $C_0 = 0$、$C_h \le Am(1 + C_{h-1})$，进而 $C_H \le \sum_{\ell=1}^{H} (Am)^{\ell}$。计数不显含全状态数，却仍可能随深度迅速增长。

我们还要判断这些有限样本能否可靠选择根动作。先保留理想子值 U_h^0，只分析一次均值估计；有界奖励和折扣使 $r + \gamma U_{h-1}^0(s') \in [-V_{\max}, V_{\max}]$。对一个动作的 m 个独立样本，Hoeffding 不等式控制样本均值的波动：偏离理想期望超过 η 的概率至多 $2\exp[-m\eta^2/(2V_{\max}^2)]$。树中需要估计的动作均值至多有 $M = A\sum_{\ell=0}^{H-1}(Am)^{\ell}$ 个。即使节点状态由祖先样本决定，在给定祖先后，该节点的新样本仍独立，且相同的概率界一致成立。因此联合失败概率至多 $2M\exp[-m\eta^2/(2V_{\max}^2)]$。

只控制根部的一次均值还不够，实际计算使用的是带误差的递归子值。在树内所有均值误差均不超过 η 的事件上，令 e_h 界住剩余 h 层的估值误差；把理想子值换成递归估计最多增加 γe_{h-1}，于是 $e_h \le \eta + \gamma e_{h-1}$、$e_0 = 0$，从而 $e_H \le \eta(1-\gamma^H)/(1-\gamma)$。根部各动作值的误差也有同样上界；按估计值选动作相对理想 H 步最优首动作的损失不超过 $2e_H$。再单独加上截断误差，才能联系无限时域目标。选择 m 使上述失败概率不超过指定 α 便得到一条充分保证；M 也依赖 m，故这是需满足的隐式条件，而不是忽略树大小的一次均值估计。

上述保证依赖独立生成查询、有限动作、奖励界，以及对整棵有限树的误差联合控制，不能只靠某个节点的均值准确。Kearns 等给出了更系统的分析：当前状态规划可以不显含全状态数，但精度要求和有效时域，即折扣尾部尚不能忽略的步数，仍可能使查询代价很高[8]。

[8] M. Kearns, Y. Mansour, A. Y. Ng, *A Sparse Sampling Algorithm for Near-Optimal Planning in Large Markov Decision Processes* In Machine Learning, 2002, vol. 49, pp. 193–208

固定 m 会为各节点预先分配相同宽度，也可以把展开数量与实际访问次数联系起来。**渐进加宽**（progressive widening）在节点访问少时保留少量候选，随着访问增加再加入动作或后继。图 2.9 对照同一个父节点的预设宽度与增长宽度；这改变的是展开预算，不会自动提供最优性保证。

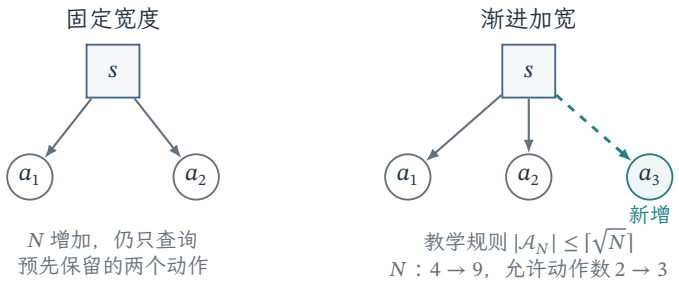


图 2.9 固定分支与渐进加宽。左侧预先只保留两个动作；右侧在节点访问次数 N 增加后加入第三个动作，虚线标记本次新增边。若加宽的是随机后继而非动作，应在每个动作节点内部另行实施，不能混为同一次动作筛选。

例如以节点访问次数 N 限制动作数为 $\lceil cN^{\beta}\rceil$，其中 $c > 0$、$0 < \beta < 1$，使候选数增长慢于访问数，给已有候选留下重复评估的预算。在连续动作中，还要说明怎样提出新动作、最优动作附近能否被采到，以及邻近动作价值是否足够接近。若加宽随机后继，保留与重采样也必须保持正确的转移概率含义。这些条件缺失时，树变大仍不构成最优性证书。

2.4.4 搜索空间外的未来价值评估

搜索在一个尚未到达终点的格子停止时，后续奖励仍属于任务，只是没有继续展开。**边界价值评估**为这部分未展开的回报给出估值，作为式 (2.16) 中的 b。零值直接忽略它；启发式从问题知识估计它；基础策略的rollout 从

叶子继续模拟既定规则，再累计后续奖励；近似价值函数则用共享参数直接求值。它们都补在同一个边界位置，但可能评价不同的后续行为。

固定示例 2.18 中的两处叶子 $p = (2, 3)$ 和 $q = (3, 2)$，它们在确定性变体中都恰好距终点两步。最佳剩余回报同为 $-0.04 + 0.9 = 0.86$。表 2.6 在这同一对叶子上比较四种接口；所有数字均为教学设定。

边界规则	$b(p)$	$b(q)$	额外调用	偏差与方差
零值	0	0	0	忽略真实剩余回报，无采样方差
距离启发式	0.9	0.9	已知距离时为 0	只计终点折扣、漏计步成本；此例高估 0.04
基础策略 rollout	0.86	0.6206	每条轨迹分别 2、4 次	基础策略在 q 多走两步；确定性模型中方差为 0
近似价值函数	0.80	0.82	求值时为 0	给定的教学预测；相对 V^* 误差分别 $-0.06, -0.04$

表 2.6 固定叶子的四类评估。rollout 基础策略在 p 走 $p \to (3, 3) \to g$，在 q 走 $q \to (3, 1) \to (4, 1) \to (4, 2) \to g$；预测数值不是训练实验结果，计算或训练这些预测的前期代价未计入在线调用。

表中的 rollout 差别来自基础策略的路线，而不是采样波动。模型随机时，rollout 估计的仍是所选基础策略 π_b 的 V^{π_b}，不自动是 V^*。平均 N 条独立完整回报可减小采样方差，却不会改变基础策略的次优性。若只模拟 L 步再置零，还会相对 V^{π_b} 留下至多 $\gamma^L V_{\max}$ 的尾误差。折扣任务可能没有自然终止，因此完整 rollout 也未必能在有限次调用内结束。

定理 2.17 给出了资源取舍：减小边界误差或增加深度，都能降低传到根部的误差上界。加深会扩大搜索树，改进叶值则可能复用之前算出的价值。不过，网络在其他区域预测准确，不能代替当前搜索叶子上的误差控制。这里先讨论如何使用叶值；跨状态表示和评价近似价值的方法由下一节展开。

2.4.5 搜索预算的自适应分配

在同一个根状态反复模拟后，有些动作已经得到较多证据，有些仍未充分评估。继续平均分配查询，不一定适合当前的动作比较。**蒙特卡罗树搜索**（Monte Carlo tree search, MCTS）保存访问统计，用已有结果决定下一次模拟路径。一次模拟沿已建树选动作，遇到未充分展开的节点时扩展，再评估叶子回报，并把沿途奖励与折扣叶值逐层回传。动作由搜索规则选择，随机后继仍由模型采样，不能混为同一种选择。

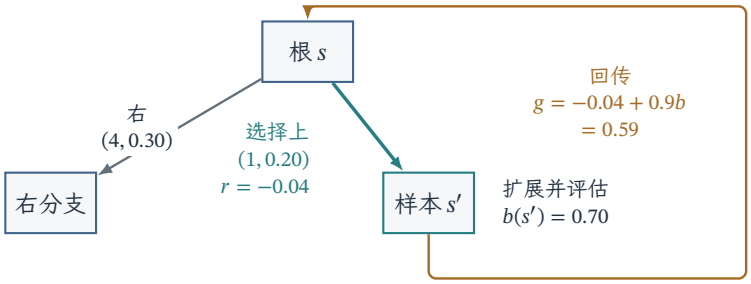
为兼顾已有高收益动作与证据较少的动作，在边 (s, a) 上记录访问次数 $N(s, a)$ 和从该边起算的平均折扣回报 $\bar{Q}(s, a)$，并令 $N(s) = \sum_a N(s, a)$。UCT（upper confidence bounds applied to trees）把平均回报与低访问动作

的探索项相加，用这个分数分配树内的下一次模拟。对已访问的合法动作，选择分数最大的一个：

$$a \in \arg\max_a \left[\bar{Q}(s,a) + c\sqrt{\frac{\log N(s)}{N(s,a)}} \right], \tag{2.18}$$

其中 $c > 0$ 应与回报范围使用相容尺度，未访问动作先至少试一次，以免分母为零。低访问动作的探索项较大，因而有机会补充证据；这个奖励用于决定查询，不是环境奖励。预算用尽后，根动作通常按访问次数或平均回报选择，不再加入探索项，报告时须明确最终规则。

图 2.10 用一条教学记录展示分数、叶值和回传怎样共同改变预算。人为给定根状态 $(1,1)$ 两条边的统计量：$N(\text{右}) = 4, \bar{Q}(\text{右}) = 0.30$，$N(\text{上}) = 1, \bar{Q}(\text{上}) = 0.20$，取 $c = 0.20$。UCT 分数分别约为 0.427 与 0.454，因此下一次模拟先试“上”。假定本次没有滑移，到达 $(1,2)$，当步奖励 -0.04，叶估值 $b = 0.70$；回传值为 $g = -0.04 + 0.9 \times 0.70 = 0.59$。这是假设的单次搜索记录，0.70 不是该状态的真实最优价值。更新后 $N(\text{上}) = 2$，$\bar{Q}(\text{上}) = (1 \times 0.20 + 0.59)/2 = 0.395$。此时两条分数约为 0.434 与 0.584，下一次仍偏向“上”。一次乐观叶估值会改变后续预算，因此访问次数大并不自行证明估值正确。



上分支更新：$N: 1 \to 2$，$\bar{Q}: (0.20 + 0.59)/2 = 0.395$
下一轮 UCT 分数：右 0.434，上 0.584（$c = 0.2$）

图 2.10 一次 MCTS 模拟及回传。边标签列出模拟前的 $(N, \bar{Q})$；本次选择“上”，扩展到样本后继，用 $b = 0.70$ 评估叶子，并回传 0.59，得到更新后的 $(2, 0.395)$。箭头旁分别标明树内选择与统计量回传，数字为正文规定的教学记录。

若路径更深，先从叶值开始，用 $g_t = r_t + \gamma g_{t+1}$ 逐层算回各边起点的回报，再更新对应边的统计量：$N \leftarrow N + 1$、$\bar{Q} \leftarrow \bar{Q} + (g_t - \bar{Q})/N$。各边的奖励起算时刻和折扣次数不同，因此不能把根部累计回报原样写入所有深度。

UCT 的探索项借鉴了老虎机的上置信界（upper confidence bound, UCB），即给证据不足的动作增加乐观估值。不过，树内下游搜索规则会不断改变，同一边以后模拟的回报分布未必与早期相同，不能直接套用固定分布老虎机的全部结论。原始 UCT 分析在有限动作、有界回报和有限

部件	无学习先验的基本搜索	AlphaZero 中的接口
环境后果	用精确规则或模型样本展开	已知棋类规则，不以学习动力学为必要条件
动作预算	根据均值和探索项分配	策略先验影响早期访问分配；先验错误可能浪费预算
叶子价值	零值、启发式或 rollout	价值网络估计当前局面结果，仍有逼近误差
搜索输出	根动作及其统计量	根访问分布提供动作选择依据，并作为策略训练目标
训练反馈	可以完全没有训练阶段	自我对弈结果训练价值；对手与数据分布随策略变化

表 2.7 已知模型搜索中规则、先验、叶值和搜索目标的不同作用。棋类回报与双方轮流行动的符号按当前玩家处理，不能直接套用单智能体网格的同向回报。

深度等条件下沿树深归纳，处理这种变化；折扣问题还需加入截断误差。即使原设定下一致，也不代表任意先验、叶网络或连续加宽方案都有相同有限样本保证[9]。

在棋类中，合法走子和状态转移由规则给定，难点是无法穷举全部后续局面。AlphaZero 把网络给出的动作先验和局面价值接入搜索：先验提示哪些动作先分配预算，价值估计尚未展开的未来，模型仍由已知规则提供。因此学习这些建议不等于学习环境动力学[10]。

具体地，AlphaZero 使用带策略先验的 PUCT 式选择，按先验概率调整探索分配，其典型探索项与 $p(a \mid s)\sqrt{N(s)}/(1+N(s,a))$ 成正比，而非直接照抄式 (2.18)。表 2.7 区分各信息的职责。

本节所需的结论是：已知规则、动作建议和叶值承担不同职责，搜索可以组合这些输入。先验与价值如何从自我对弈中改进、对手和训练数据分布怎样随之变化，则涉及多个决策者的共同学习，由第 7 章继续分析。

[9] L. Kocsis, C. Szepesvári, *Bandit Based Monte-Carlo Planning* In Machine Learning: ECML 2006, 2006, pp. 282–293

[10] D. Silver, T. Hubert, J. Schrittwieser, I. Antonoglou, M. Lai, A. Guez, M. Lanctot, L. Sifre, D. Kumaran, T. Graepel, T. Lillicrap, K. Simonyan, D. Hassabis, *A General Reinforcement Learning Algorithm That Masters Chess, Shogi, and Go through Self-Play* In Science, 2018, vol. 362, no. 6419, pp. 1140–1144

2.5 面向全状态的近似规划

导航过程中可能多次遇到同一位置或相似局面，局部搜索每次都重新计算，未必能充分复用已有工作。另一条近似路线保存一个跨状态的价值函数，用有限共享参数代替整张表。它可以减少存储和重复计算，却也使一次更新同时改变多个状态的预测，必须分析这种共享怎样影响评价与动作选择。

2.5.1 全状态规划的挑战

基准网格的 11 个合法位置可以各存一个价值。如果导航还要考虑 q 种物品库存，每种有 L 个取值，状态就从单独位置扩大为位置与库存的组合，共有 $11L^q$ 个。取教学规模 $L=10, q=6$，已有 1100 万个状态；每值占 8 字节，仅价值表便需 8800 万字节。进一步加入时间、动作或设备，转移表示还会增长。各库存的变化规则即使很简短，也不意味着所有组合都能低成本枚举。

压缩价值表示以后，一次规划更新仍包含不同计算。图 2.11 中，表示确定哪些状态共享参数，Bellman 备份计算转移期望，拟合用所选函数类近似备份目标，动作选择再做最大化。因此要分清存储不足、期望估计误差、表示或拟合误差，以及动作优化误差，不能把它们当成同一个困难。

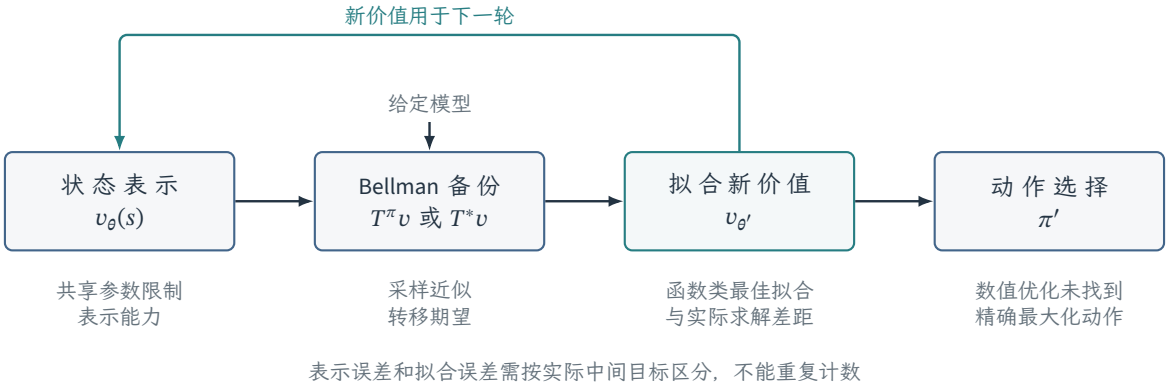


图 2.11 全状态近似的共同计算接口。实线表示当前一轮的信息传递，外侧回路表示把新价值送往下一轮；下方分别标出表示、期望估计、拟合和动作优化可能产生的误差。给定模型仍是备份的输入。

这些计算仍以给定模型为输入。为了减少精确求和而使用模型样本，会留下有限样本的期望估计误差；模型本身若由真实交互学得，还会偏离环境规律，那是下一章要加入的另一层误差。本节只分析给定模型上的表示和求解，不把两种误差混称为来源不明的预测误差。

2.5.2 跨状态近似价值的表示

要用少数参数替代价值表，最直接的办法是让一组状态共用一个值。**状态聚合**（state aggregation）就是这种分组表示：取映射 $g : \mathcal{S} \to \{1, \dots, p\}$，令 $v(s) = \theta_{g(s)}$，一次更新 θ_i 会改变第 i 组的所有预测。分组应保留与回报有关的差别，而不只是把几何上邻近的位置放在一起。

基函数展开让状态通过给定特征共同使用参数，以特征的加权和计算价值。用 $\boldsymbol{\phi}(s) \in \mathbb{R}^p$ 表示特征、θ 表示权重，写成 $v_\theta(s) = \boldsymbol{\phi}(s)^\top \theta$。例如在网格中取 $\boldsymbol{\phi}(s) = (1, x/4, y/3)^\top$，只保存 3 个参数，就能为各位置求值；代价是只可表示坐标的仿射函数，不能任意指定 11 个价值，也不会自行刻画障碍绕行。若用组指示函数作特征，就恢复了状态聚合。一般参数化函数 $v_\theta(s)$，如神经网络，还能表示非线性关系，但所能表达的函数仍取决于结构和参数数目。

图 2.12 用同一网格检查分组会丢失什么。按行聚合把障碍两侧的 $(1,2)$ 和 $(3,2)$ 放在同组，但两处最优价值约为 0.501527 和 0.801271。共享常数不可能同时等于它们，最大误差至少为差值的一半，约 0.149872。按到达终点的通道划组能够保留两侧差别，却没有证明组内所有价值相同；还须继续检查组内误差。

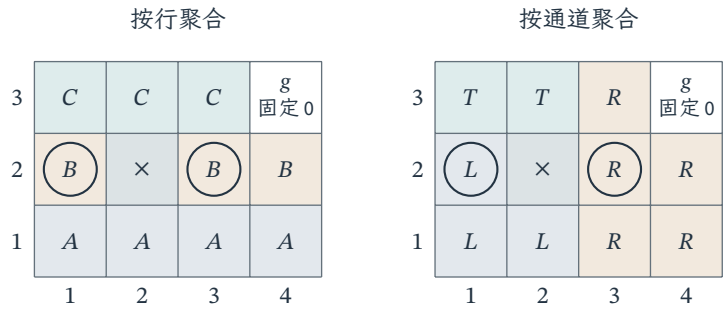


图 2.12 同一基准网格的两种教学聚合。左图按行分成 A、B、C 组，右图按障碍周围的通道分成 L、T、R 组；非终点格的字母表示共享参数，终点价值固定为 0，颜色仅作辅助。右图保留了障碍两侧的区别，但不是精确 MDP 同态或零误差聚合的声明。

表 2.8 分别比较一次价值求值与一次单状态参数更新所需的资源。更灵活的函数类可能减小表示偏差，但投影迭代未必更稳定，数值优化也未必能找到最佳拟合。

表示	参数存储	求值／单样本更新	表达范围与限制
全状态表	$O(n_S)$	$O(1)$ ／ $O(1)$	可独立表示每个状态，不含模型存储
p 组聚合	$O(p)$	$O(1)$ ／ $O(1)$	假设组索引可常数时间取得；组内差别全部丢失
p 维稠密线性特征	$O(p)$	$O(p)$ ／ $O(p)$	只能表示特征张成空间；未计特征构造和批量解方程
一般参数化函数	参数数 P	依计算图而定	前向与反向代价须按架构计数；非凸拟合与泛化另需分析

表 2.8 价值表示的资源口径。一次函数求值不包括 Bellman 备份所需的多后继求值；动作价值 $q(s,a)$ 若为每个动作单独输出，还需计入动作维。

2.5.3 策略的近似价值评估

固定策略 π 和线性函数空间 $\mathcal{F}$ 后，我们要在有限表示中评价它的真实价值。若已知 V^π，可以直接回归；通常未知的正是这个函数，能够使用的是模型给出的 Bellman 关系。为比较这几种近似对象，固定状态权重 $\xi(s) > 0$、$\sum_s \xi(s) = 1$，以 $\|v\|_\xi^2 = \sum_s \xi(s) v(s)^2$ 计量加权平方大小。优化时在同一个 $\mathcal{F}$ 中寻找对应误差最小的函数；投影则把备份结果变成该加权平方距离下最接近的可表示函数。

定义 2.19 三种近似评价对象 令 Π_ξ 为到 $\mathcal{F}$ 的 ξ 加权正交投影。以下三种问题分别为

$$\begin{aligned} &\text{价值拟合：} && \min_{v\in\mathcal{F}} \|v - V^\pi\|_\xi^2, \\ &\text{残差最小化：} && \min_{v\in\mathcal{F}} \|v - T^\pi v\|_\xi^2, \\ &\text{投影方程：} && v = \Pi_\xi T^\pi v, \qquad v \in \mathcal{F}. \end{aligned}$$

前两者最小化不同误差；第三者要求一次备份后投影回来不再改变 v，并不要求原始 Bellman 残差为零。

定义中的价值拟合直接缩小预测与 V^π 的差，残差最小化缩小预测与自身备份的差；投影方程则寻找备份再投影后的不变点。因此后两者不要求先取得真实标签，也不保证给出第一种答案。在线性表示中，我们可以将投影方程化为关于参数的线性系统：用 $\boldsymbol{\Phi} \in \mathbb{R}^{n_S \times p}$ 的第 s 行为 $\boldsymbol{\phi}(s)^\top$，$\boldsymbol{D} = \operatorname{diag}(\xi)$，并假设 $\boldsymbol{\Phi}$ 列满秩。投影矩阵为 $\boldsymbol{\Pi}_\xi = \boldsymbol{\Phi}(\boldsymbol{\Phi}^\top \boldsymbol{D} \boldsymbol{\Phi})^{-1} \boldsymbol{\Phi}^\top \boldsymbol{D}$。将 $\boldsymbol{v} = \boldsymbol{\Phi}\boldsymbol{\theta}$ 代入投影方程并乘 $\boldsymbol{\Phi}^\top \boldsymbol{D}$，得到

$$\underbrace{\boldsymbol{\Phi}^\top \boldsymbol{D}(\boldsymbol{I} - \gamma \boldsymbol{P}^\pi)\boldsymbol{\Phi}}_{\boldsymbol{A}}\,\boldsymbol{\theta} = \underbrace{\boldsymbol{\Phi}^\top \boldsymbol{D}\boldsymbol{r}^\pi}_{\boldsymbol{b}}. \tag{2.19}$$

式 (2.19) 把函数不变条件压缩成 p 个参数的方程。但 $\boldsymbol{\Phi}$ 列满秩只保证投影矩阵中的逆存在，不自动保证这里的 $\boldsymbol{A}$ 可逆。只有后者可逆，$\boldsymbol{A}^{-1}\boldsymbol{b}$ 才是唯一参数解；若奇异，还需检查有无解、怎样选解，或是否另加正则化。正则化是改变方程的求解选择，不是原方程无条件可解的证明。

示例 2.20 同一特征的三种答案 构造一个独立的两状态、单动作教学模型，$\gamma = 1/2$，

$$\boldsymbol{P}^\pi = \begin{pmatrix} 0 & 1 \\ 0 & 1 \end{pmatrix}, \quad \boldsymbol{r}^\pi = \begin{pmatrix} 1 \\ 0 \end{pmatrix}, \quad \boldsymbol{\Phi} = \begin{pmatrix} 1 \\ 2 \end{pmatrix}, \quad \boldsymbol{D} = \tfrac{1}{2}\boldsymbol{I}.$$

精确价值为 $(1,0)^\top$。价值拟合最小化 $\frac{1}{2}[(\theta-1)^2 + 4\theta^2]$，故 $\theta = 1/5$。原始残差为 $(\theta, 2\theta)^\top - (1+\theta, \theta)^\top = (-1, \theta)^\top$，所以残差最小化给 $\theta = 0$。

对投影方程，$(\boldsymbol{I} - \gamma\boldsymbol{P}^\pi)\boldsymbol{\Phi} = (0,1)^\top$，因而 $\boldsymbol{A} = 1$、$\boldsymbol{b} = 1/2$，解为 $\theta = 1/2$。若每轮先备份再投影，参数更新为 $\theta^{(k+1)} = 1/5 + (3/5)\theta^{(k)}$，也收敛到 $1/2$。三者不同不是数值误差，而是目标不同。

直接解方程之外，也可以反复备份再投影，但精确评价的收敛证明还需要复合算子 $\Pi_\xi T^\pi$ 保持压缩。一个充分条件是 ξ 为 $\boldsymbol{P}^\pi$ 的严格正平稳分布，即按这个分布转移一步后分布不变。此时由 Jensen 不等式，

$$\|\boldsymbol{P}^\pi v\|_\xi^2 \le \sum_s \xi(s) \sum_{s'} P^\pi(s,s') v(s')^2 = \|v\|_\xi^2 .$$

第一个不等式说明平方的加权平均不小于平均后的平方，最后的等式使用 ξ 的平稳性。正交投影在同一 ξ 范数下也不放大距离，二者复合再乘 γ，便得到压缩和唯一投影固定点。例 2.20 并无严格正平稳权重，但其参数更新斜率 $3/5 < 1$ 直接给出收敛；刚才列的是充分条件，不是必要条件。

一般权重未必满足平稳等式，而最小二乘投影在无穷范数下也未必不放大距离，所以不能默认备份再投影稳定。若还能算出原始残差的全状态上界，式 (2.3) 仍可为拟合结果提供价值误差证书；仅有投影残差为零则不够。只有模型样本时，残差梯度还涉及同一状态动作下如何组合独立后继样本，称为双重采样问题，由第 3 章展开。

2.5.4 基于近似价值的策略改进

上一小节在所选函数类中评价了固定策略，现在要用这个近似结果改动作。若保存状态价值 v，需要模型把它转为当前各动作的比较量 $R(s,a)+\gamma P_a v$，其中 $P_a v = \sum_{s'} P(s' \mid s,a) v(s')$。若保存动作价值 $q(s,a)$，则在合法动作中直接比较 q。后一种接口省去行动时的一步期望计算，但动作后果是否估准，仍取决于 q 的误差。即使估值给定，实际动作优化也可能没有取到最大值；下面把这项选择误差与估值误差分开。

定义 2.21　近似贪心误差　对状态价值 v，策略 π' 的模型贪心误差为

$$\eta(v,\pi') = \|T^* v - T^{\pi'} v\|_\infty .$$

因 $T^* v \ge T^{\pi'} v$，它衡量实际动作选择比精确最大化少了多少一步备份价值。对给定动作价值 q，对应地考察

$$\sup_s \left[\max_a q(s,a) - \sum_a \pi'(a \mid s) q(s,a) \right].$$

这里的无穷范数或上确界覆盖所有状态，比较方向是实际策略的备份比合法动作最大值少多少，避免某个状态的选择误差被平均掉。即使 v 准确，连续动作上的数值求解仍可能留下 $\eta > 0$；即使精确最大化 q，动作价值估计也可能不准确。因此有限动作的枚举与连续动作的数值优化应分别说明，后者还须给出约束、优化器和精度。

估值和动作选择都可以放进迭代循环，但位置不同会改变每轮所求的对象。表 2.9 用同一组评价、拟合和改进操作对照三种安排；$\mathcal{F}$ 为选定函数类，拟合用该类中的函数近似备份目标。特别是最优备份内部选了一次动作，不等于已经精确评价这份策略的长期价值。

循环	每轮备份与拟合	动作选择的位置
近似策略迭代	固定 $\pi^{(k)}$，用若干次评价备份及拟合得到 $v^{(k)} \approx V^{\pi^{(k)}}$	评价结束后对 $v^{(k)}$ 近似贪心
近似价值迭代	一次 $T^* v^{(k)}$ 后拟合一次，得 $v^{(k+1)} \in \mathcal{F}$	每次最优备份内部都比较动作
修改策略迭代	先取 $\pi^{(k+1)}$，再做 m_k 次 $T^{\pi^{(k+1)}}$；近似版本还需注明每次或最后拟合	每个外层循环开始时一次

表 2.9 共享接口下的不同循环。$m_k = 1$ 且没有拟合时，修改策略迭代退化为价值迭代；最优备份不意味着已经精确评价了所选策略。

用一个只剩一步的教学问题检查误差会怎样改变选择。真实动作价值为 $Q(a) = 0.50, Q(b) = 0.49$，若估计误差分别为 $-0.01, +0.01$，就得到 $q(a) = 0.49, q(b) = 0.50$，精确贪心也会选 b。最大估值误差为 0.01，已经足以翻转两动作的排序；若旧策略选 a，新策略真实回报反而下降 0.01。所以近似改进不继承每轮单调提高的无条件保证，下一步要把评价误差和动作选择误差带入长期性能分析。

2.5.5 误差传播与策略性能损失

一次备份可能受到表示、采样和数值优化的共同影响。为分析这些误差随迭代怎样传播，先把实际更新与同一输入上的理想备份相减，写成 $v^{(k+1)} = T^* v^{(k)} + e^{(k)}$。这里 $e^{(k)}$ 包含这一轮相对理想最优备份的全部误差。若要分解其来源，可以在理想目标与实际输出之间，依次插入动作优化后的期望目标、采样目标、函数类中的最佳拟合和实际拟合结果。相邻结果之差对应动作优化、期望估计、表示不足和拟合求解误差，用三角不等式界住总差。每次比较必须使用说明过的范数；加权二范数下的最佳拟合，未必也是最大状态误差最小的拟合。

图 2.13 将旧误差与新误差分开：理想算子的压缩性减小上一轮的价值误差，本轮 $e^{(k)}$ 又使结果偏离理想备份。若动作优化误差已计入 $e^{(k)}$，就不能在总界 δ 中重复加入；最终从价值表另行提取策略所产生的近似贪心误差，才是另一处需要计量的误差。下面用每轮全状态总误差不超过 δ 的条件，控制价值和输出策略的性能。

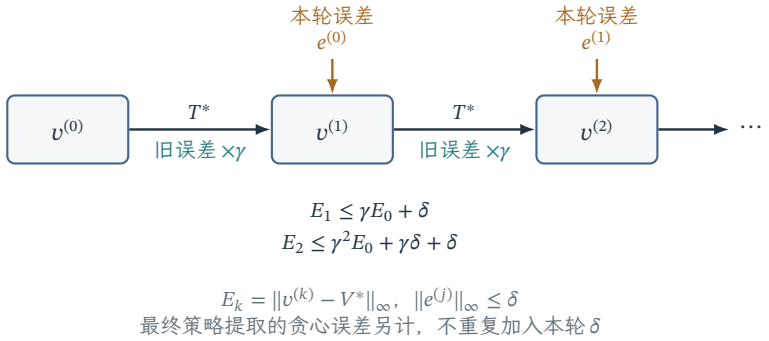


图 2.13 近似价值迭代的误差传播。横向每经过一次理想 Bellman 备份，旧误差乘 γ；上方 $e^{(k)}$ 在各轮注入。因此第 j 轮的误差对第 k 轮的贡献按 γ^{k-1-j} 衰减，而每轮都持续注入的误差不会消失。

定理 2.22 近似价值迭代的统一误差界 若每轮满足 $\|v^{(k+1)} - T^* v^{(k)}\|_\infty \le \delta$，则

$$\|v^{(k)} - V^*\|_\infty \le \gamma^k \|v^{(0)} - V^*\|_\infty + \frac{\delta(1-\gamma^k)}{1-\gamma}. \tag{2.20}$$

若输出策略 $\pi^{(k)}$ 对 $v^{(k)}$ 的贪心误差不超过 η，其真实性能满足

$$\|V^* - V^{\pi^{(k)}}\|_\infty \le \frac{2\gamma\|v^{(k)} - V^*\|_\infty + \eta}{1-\gamma}.$$

证明 记 $E_k = \|v^{(k)} - V^*\|_\infty$。插入 $T^* v^{(k)}$ 并使用压缩性，

$$E_{k+1} \le \|v^{(k+1)} - T^* v^{(k)}\|_\infty + \|T^* v^{(k)} - T^* V^*\|_\infty \le \delta + \gamma E_k.$$

连续代入得到 $E_k \le \gamma^k E_0 + \delta \sum_{j=0}^{k-1} \gamma^j$，计算几何和即为第一式。

提取策略时，插入 $T^* v^{(k)}$ 及 $T^{\pi^{(k)}} v^{(k)}$，两者差至多 η。其余两项分别用最优算子和策略算子的压缩性控制，得到

$$\|V^* - V^{\pi^{(k)}}\|_\infty \le 2\gamma E_k + \eta + \gamma \|V^* - V^{\pi^{(k)}}\|_\infty.$$

移项即得第二式；$\eta = 0$ 时正好回到精确贪心性能界。 ■

在教学参数 $\gamma = 0.9$、每轮统一误差 $\delta = 0.001$ 下，几何累积给出渐近价值误差上界 0.01，再转成精确贪心策略的损失上界为 0.18。误差先在价值迭代中累积，又在长期执行的性能比较中放大；两个分母各有来源。这些是可能保守的解析上界，不表示实际网格正好损失相应数值。

上界使用最大状态误差，而拟合目标可能只控制加权二范数，两种精度不能直接交换。假设一个状态在拟合分布中仅有 10^{-6} 概率，误差为 1，其

他状态误差为 0，加权二范数仍只有 10^{-3}。部署若恰好从这个状态开始，低权重下的小误差指标就没有控制初始决策。要将加权误差转成性能界，还需限制部署占用相对采样分布的偏移，例如要求覆盖并控制密度比，即同一状态在两分布中的概率之比。原分布给零概率的状态，也不能靠增加该分布上的样本数覆盖。生成模型下拟合价值迭代的有限时间分析因此保留函数类逼近能力和未来状态分布的集中性条件[11]。

近似策略迭代每轮评价的是一份变化中的策略，不是直接近似一次 T^* 更新，所以式 (2.20) 的假设不再对应。我们改为控制每轮估值离当前策略真实价值的最大误差。若 $\|v^{(k)} - V^{\pi^{(k)}}\|_\infty \le \varepsilon$，改进误差不超过 η，则 $T^{\pi^{(k+1)}} V^{\pi^{(k)}} \ge T^* V^{\pi^{(k)}} - \beta \ge V^{\pi^{(k)}} - \beta$，其中 $\beta = 2\gamma\varepsilon + \eta$。比较 $T^* v^{(k)}$ 与 $T^{\pi^{(k+1)}} v^{(k)}$ 给出 η，把两边估值换回真实 $V^{\pi^{(k)}}$ 各付出至多 $\gamma\varepsilon$，便得到这项不等式。为把一次可能下降的备份转成新策略真实价值的下降界，利用恒等式

$$V^{\pi'} - V^{\pi} = (\boldsymbol{I} - \gamma \boldsymbol{P}^{\pi'})^{-1} (T^{\pi'} V^{\pi} - V^{\pi})$$

这里 $\pi = \pi^{(k)}$、$\pi' = \pi^{(k+1)}$。逆矩阵的几何级数非负，行和为 $1/(1-\gamma)$，因而备份下降至多 β 时，真实价值满足 $V^{\pi'} \ge V^{\pi} - \beta/(1-\gamma)$。再比较新策略与最优价值，在两者之间插入 $T^* V^{\pi}$ 和 $T^{\pi'} V^{\pi}$，逐状态得到

$$\begin{aligned} V^* - V^{\pi'} &= T^* V^* - T^{\pi'} V^{\pi'} \\ &\le \gamma \|V^* - V^{\pi}\|_\infty + \beta + \gamma \boldsymbol{P}^{\pi'} (V^{\pi} - V^{\pi'}) \\ &\le \gamma \|V^* - V^{\pi}\|_\infty + \frac{\beta}{1-\gamma}. \end{aligned}$$

由于 $V^* \ge V^{\pi'}$，对状态取最大值得到保守递推 $\|V^* - V^{\pi^{(k+1)}}\|_\infty \le \gamma \|V^* - V^{\pi^{(k)}}\|_\infty + \beta/(1-\gamma)$，将这项递推展开为几何和，渐近损失至多 $\beta/(1-\gamma)^2$。这里控制的是每轮相对当前策略真实价值的评价误差；AVI，即近似价值迭代，控制的则是一次最优备份误差，二者不能混用。更细的加权范数和不同迭代安排的误差传播可见 Farahmand 等[12]。

[11] R. Munos, C. Szepesvári, *Finite-Time Bounds for Fitted Value Iteration* In Journal of Machine Learning Research, 2008, vol. 9, pp. 815–857

[12] A.-m. Farahmand, C. Szepesvári, R. Munos, *Error Propagation for Approximate Policy and Value Iteration* In Advances in Neural Information Processing Systems, 2010

2.6 可计算性与复杂度边界

同一次 Bellman 备份可能逐项求和，也可能重复采样，连续动作还要调用数值优化器。它们在伪代码中都可能只有一行，实际代价却不同。现在沿用前面各方法的输入接口，分别计算它们为所需输出和精度付出多少运算、存储与查询；只有这些单位固定，迭代次数少或计数不含状态数才有明确含义。

2.6.1 复杂度指标与模型访问

为比较一次精确扫描与一棵采样树，先分清资源的计量单位。**算术运行时间**数加法、乘法等基本运算，**存储复杂度**数同时保留的模型、价值、策略和搜索节点。**并行深度**数即使有无限处理器仍须顺序完成的依赖层数，**模型调用复杂度**则数调用外部模型接口的次数。并行可以缩短依赖允许范围内的延迟，但不会自动减少总运算或总样本数。

表 2.10 对应四种模型表示的基本操作。读取一个表项、遍历一个后继集合和取得一个随机样本，返回的信息量不同；因此必须先规定一次访问指什么，再比较调用次数。

模型表示	基本访问操作	一次备份仍需付出的代价
显式稠密转移表	读取一个概率或奖励表项	对 n_S 个后继求和；需要整个模型的存储
稀疏转移表	遍历一个状态动作的非零后继	对 b 个后继求和，并读取对应价值
解析动力学	计算状态转移或积分表达式	单次函数代价依公式而定；有公式不等于积分可解析
生成模型	给定 (s,a) 取得一个独立 (r,s')	用样本均值估计期望；还须计样本数与失败概率

表 2.10　不同模型访问协议的计数单位。表中 b 表示非零后继数；生成模型的一次查询通常只产生一个后继，不能与遍历整行概率等价计数。

以同一个后继期望 $P_a v$ 为例，稀疏精确模型要读取 b 个后继价值并加权求和，没有采样误差。生成模型用 m 个后继样本的均值近似它，调用代价随 m 增加，精度则要附带失败概率。即使 $m<b$，也只是以更少查询换取近似结果；比较同精度下的速度，还要说明两者误差标准如何对齐。

输出要求也要固定。全状态价值精度约束每个坐标，给定 ρ_0 的策略精度约束其回报差，当前状态选择则只需控制一个根决策的损失。三者不同，不能共用所有下界：写出 n_S 维显式价值表本身至少需要 $\Omega(n_S)$ 次写入，而输出一个根动作不需要写出这张表。

下面将一次基本算术运算按单位成本计数。若进一步计算位复杂度，即处理数字的二进制编码所需的工作，还要考虑输入概率的位长、目标精度和精确消元中的分子分母增长。多项式算术步数并不意味着每一步的位运算都只需常数成本；采用浮点实现时，舍入误差也应纳入残差证书。

2.6.2 全状态动态规划的计算代价

先数一次精确最优 Bellman 扫描的工作。设状态数为 n_S，每处合法动作至多 n_A，实际状态动作对的平均非零后继数为 b。扫描逐个状态枚举动作，再遍历各动作的后继；状态动作对至多 $n_S n_A$ 个，每对平均付出 b 次后继计算，因此代价上界为

$$O(n_S n_A b). \tag{2.21}$$

若转移稠密，$b = n_S$，一次扫描便为 $O(n_S^2 n_A)$。稀疏模型及奖励占 $O(n_S n_A b)$ 存储，价值表占 $O(n_S)$；确定性策略每状态只存一个动作索引，共 $O(n_S)$ 个字，随机策略则至多存 $O(n_S n_A)$ 个概率。同步更新多留一张价值表，但价值存储阶仍为 $O(n_S)$，模型存储要另外计入。

总运行时间还要乘扫描轮数。压缩性给出第 k 轮误差至多 $\gamma^k E_0$，其中 E_0 界住初始误差；要使它不超过 ε，在 $0 < \gamma < 1$、$0 < \varepsilon < E_0$ 时解这个不等式，得到充分轮数

$$k \geq \left\lceil \frac{\log(E_0/\varepsilon)}{-\log \gamma} \right\rceil. \tag{2.22}$$

从零初始化时，有界回报给出 $E_0 = R_{\max}/(1-\gamma)$。利用 $-\log\gamma \geq 1-\gamma$，可以进一步采用较保守的 $O((1-\gamma)^{-1}\log(E_0/\varepsilon))$ 轮数上界。γ 越接近 1，未来影响衰减越慢，达到同一精度可能需要更多轮。边界也要分开：$\gamma = 0$ 时一次备份已最优，$\varepsilon \geq E_0$ 时初值已满足精度，都无须使用对数式。

表 2.11 将各操作的单轮成本与轮数要求分开。固定确定性策略只使用一个动作，稠密随机策略还要按动作概率混合，或提前构造 $\boldsymbol{P}^{\pi}, \boldsymbol{r}^{\pi}$。若直接解稠密 n_S 阶评价方程，常规消元需 $O(n_S^3)$ 运算及 $O(n_S^2)$ 存储。稀疏消元可能产生填充，即原本为零的位置在消元中变成非零，所以不能仅将 b 代入稠密立方公式，就认定得到稀疏求解代价。

操作	单轮算术代价	轮数或输出条件
固定确定性策略的迭代评价	一次固定策略扫描 $O(n_S b_\pi)$	b_π 为所选动作平均后继数；轮数由评价压缩或残差确定
策略改进	$O(n_S n_A b)$	只比较一次动作；不包括评价
价值迭代	$O(n_S n_A b)$	达到价值误差的轮数见式 (2.22)
精确策略迭代	稠密评价 $O(n_S^3)$ 加改进；模型混合另计	外层轮数依问题而变；有限终止论证只给有限策略数的粗界

表 2.11　全状态动态规划的成本。b_π 可能与所有动作平均的 b 不同；表中随机策略若未预先混合转移，评价扫描还需计入动作枚举。

前面的有限终止证明只用到了确定性策略总数 $\prod_s |\mathcal{A}(s)|$。它对 n_S 可能指数增长，因此既不是紧的轮数分析，也不是多项式时间结论。若要作更细比较，必须说明策略迭代的具体规则、折扣是否固定，以及复杂度定理所计的输入与运算。

同步扫描内，各状态动作的后继求和可以并行。令 $b_{\max}$ 为最大非零后继数，树状求和再比较动作最大值的依赖深度为 $O(\log(1+b_{\max})+\log(1+n_A))$；这里必须用最大值而不是平均 b，因为并行延迟由最长计算链决定。第 $k+1$ 轮仍使用第 k 轮的价值，所以有足够处理器也不能将所有轮次同时完成。

2.6.3 时域、分支与搜索复杂度

局部搜索省去了全状态扫描，却可能反复展开同一位置的不同历史。为数完整树的规模，固定每处 A 个动作、每个动作 B 个随机后继，并以动作执行次数计深度 H。每层状态节点增加 AB 倍，因此状态节点总数为 $\sum_{h=0}^{H}(AB)^h$，非叶状态处的动作节点数为 $A\sum_{h=0}^{H-1}(AB)^h$。当 $AB>1$ 时，前者为 $[(AB)^{H+1}-1]/(AB-1)$，随深度指数增长；$AB=1$ 时则只有一条长度 H 的链，不能使用分母为 0 的几何和形式。

若两条历史到达同一网格位置，且剩余步数相同，马尔可夫性保证它们面对同一个后继子问题。于是可合并相同的 $(s,\text{剩余深度})$，用动态规划图复用结果；连终端层在内至多有 $(H+1)n_S$ 个时层状态，其中至多 Hn_S 个需要备份。合并要支付状态识别与存储成本，利用的是信息充分性，而非删除真实随机后果。连续状态很少精确重复时，这种复用可能收益有限。

表 2.12 回到同一棵搜索树，比较截断、采样、叶值、自适应访问和状态合并各省去什么工作。稀疏采样将每动作后继数 B 替换为 m，仍保留 $(Am)^H$ 的深度依赖；MCTS 只展开访问到的节点，但减少节点不等于普遍改善固定预算下的最坏决策误差。

手段	减少的计算	误差及额外条件
深度截断	删除 H 步之后的展开	尾和或 $\gamma^H\varepsilon$ 终端误差；短视不可逆动作仍危险
稀疏采样	每个动作只抽 m 个后继	样本均值及递归误差；独立生成模型、置信度和树规模
叶值近似	用一次求值替代叶外模拟	叶值必须在到达区域准确；预计算和训练代价另计
MCTS	将查询集中于被选择的分支	回报非平稳、叶值偏差与探索条件；选择性展开不是普遍最坏界
状态合并	复用相同状态及剩余深度的计算	要求表示保留决策所需信息，并支付索引与存储成本

表 2.12　搜索预算的节省对象。不同手段可以组合，但组合后的误差应按实际接口重新分析。

若一次 MCTS 模拟至多走 H 层，每层只抽一个后继，叶值评估又需 L 次模型调用，则调用至多为 $H+L$，N 次模拟至多为 $N(H+L)$。这个计数不含动作枚举、网络求值或连续优化，也没有说明误差随 N 减小多快。模拟长度随机时，还应分别报告期望调用和尾部延迟；平均用时小于预算不保证每次都在截止时间内返回。

2.6.4 计算下界

前面的上界数了具体算法的工作。若想知道还能省去多少，就要寻找某类输入上任何算法都必须读取的信息。我们构造**不可区分问题对**：两种环境在已读记录上完全相同，未查部分却使最优动作不同。算法只凭共同记录作选择，就不能在两种环境中都保证正确；这给出了指定接口下的资源下界。

先隔离精确表项的读取代价。一个单步问题有 A 个动作，算法已读奖励都为 0，未查动作中可能有一个奖励为 1。若还剩至少两个未查动作，就可以分别把唯一奖励 1 放在它们上面，得到相同读取记录和不同最优动作。因此要求精确最优的确定性算法，最坏至少要查 $A-1$ 个表项；扫描全表给出 $O(A)$ 上界。奖励没有随机性，必要信息仍须付出读取成本。

换成生成模型，一次读到的奖励不再确定其期望，我们就要数样本辨识的代价。考虑单状态、单步、两动作，即 $H=1$、没有后续奖励，也等价于 $\gamma=0$。奖励在 $[0,1]$ 内，动作 a_1 恒得 $1/2$，动作 a_2 在模型 M_+ 和 M_- 中分别服从 Bernoulli$(1/2+2\varepsilon)$ 和 Bernoulli$(1/2-2\varepsilon)$，其中 $0<\varepsilon\le 1/8$。要求算法输出一个确定性根动作，并在模型样本及自身随机性下，以至少 $1-\alpha$ 的概率使该动作期望奖励离最优不超过 ε，其中 $0<\alpha<1/4$。两模型的最优动作相反，选错会损失 2ε，所以达到精度要求就必须分辨它们。

两个模型的一次样本分布很相近，单样本 KL 散度只为 $O(\varepsilon^2)$。例如用 $D_{\mathrm{KL}}(\mathrm{Ber}(p)\|\,\mathrm{Ber}(q))\le (p-q)^2/[q(1-q)]$ 即可得到统一常数界。自适应查询记录的 KL 链式法则给出总散度至多 $C\varepsilon^2\mathbb{E}_+N_2$，其中 N_2 为查询 a_2 的次数，C 为绝对常数。二元检验的两类错误概率之和至少为 $\frac{1}{2}\exp[-D_{\mathrm{KL}}(\mathbb{P}_+\|\mathbb{P}_-)]$，而成功要求使该和不超过 2α。因而

$$\mathbb{E}_+N_2\ge\frac{\log(1/(4\alpha))}{C\varepsilon^2}.$$

这说明记录必须积累足够的分布差别，才能达到规定的检验成功率。对 $\alpha\le 1/8$，所需样本阶为 $\Omega(\varepsilon^{-2}\log(1/\alpha))$。反过来，用固定次数独立样本估计 a_2 均值，与 $1/2$ 比较，Hoeffding 不等式给出同阶上界。若接口直接返回精确期望，只查一次就能区分二者，这条样本下界随即不适用。

再将困难放在未查搜索分支中，而不是奖励采样中。考虑深度 H、每层 $A\ge 2$ 动作的完整确定性树，目标有限时域且不折扣。此前奖励都为 0，A^H 个终端叶子中恰有一个得 1，其余为 0；结构已知，但只能逐次精确查询叶奖励，没有可利用的参数关系或内部节点摘要。要求以至少 $2/3$ 概率输出损失不超过 $\varepsilon<1/2$ 的确定性根动作，也就是选中包含奖励叶的根分支。

若把唯一奖励叶在 A^H 个位置均匀放置，至多 q 次查询发现它的概率不超过 q/A^H。固定算法的随机种子后，在所有查询都返回 0 的记录上，算法只能输出某个根分支；该分支最多包含全部叶子的 $1/A$，所以“未发现且猜对”这一联合事件的概率至多为 $1/A$。对随机种子取平均，界仍成立。因此总体成功率不超过 $q/A^H+1/A$，要达到 $2/3$，必有 $q\ge A^H/6$。这个平均输入论证也推出某个输入上的随机算法预算下界；扫描全部叶子则给匹配上界。指数困难来自没有结构的叶奖励表，不能把它推广为所有简洁模型的不可解性，或声称共享状态的网格必然需要同样多的查询。

表 2.13 分别将三个受限问题族的下界与同条件上界并列。每行数量级匹配，含义是该行指定任务所需资源的阶已确定；行间接口、精度和成功概率不同，不能合并为一般 MDP 的统一最优复杂度。

输入、目标与接口	下界	同条件上界	匹配范围
单步 A 动作、精确奖励表、精确最优动作	$\Omega(A)$	$O(A)$	表项读取次数，不是随机样本数
单步两动作 Bernoulli 模型、$\varepsilon \le 1/8$、$\alpha \le 1/8$	$\Omega(\varepsilon^{-2}\log(1/\alpha))$	$O(\varepsilon^{-2}\log(1/\alpha))$	独立生成样本；常数因子未追求一致
完整确定树、唯一奖励叶、根动作成功率 2/3	$\Omega(A^H)$	$O(A^H)$	精确叶奖励查询；不含到叶路径执行成本

表 2.13　三个受限问题族中的上、下界。它们分别隔离输入读取、统计辨识和搜索宽深度，不能合并为一个适用于所有 MDP 的复杂度公式。

若从这些受限问题族回到一般有限折扣 MDP，还要计入 n_S, n_A, γ 及全状态策略误差。极小极大样本率比较指定问题类中最坏输入上的最少样本需求；接近这个率需要更细的方差与依赖分析。例如经验模型规划可调用高精度规划器作为内部模块，但外部样本保证不等于内部规划的运行时间保证[13]。它也不是精确概率表的读取下界。真实在线交互通常还不能查询未到达状态，将进一步增加探索和可达性困难，下一章会另行分析。

[13] A. Agarwal, S. Kakade, L. F. Yang, *Model-Based Reinforcement Learning with a Generative Model is Minimax Optimal* In Proceedings of Thirty Third Conference on Learning Theory, 2020, pp. 67–83

2.7 本章小结

章首的问题现在可以分成两步回答：准确模型给出了计算长期后果的依据，所需输出和预算决定我们能算到哪里。在基准网格上，精确 Bellman 求解和占用量线性规划都得到同一个最优起点价值 $J(\pi^*) \approx 0.42116103368346147$；均匀策略的值为 -0.15475437784251433。最优策略与均匀策略的回报差来自行动方式，而不是更换奖励或滑移规则。价值评价各状态的长期后果，占用量记录策略怎样分配折扣时间；二者由 $J(\pi) = (1-\gamma)^{-1}\sum_{s,a} d^{\pi}(s,a)R(s,a)$ 联系，所以归一化流量恢复为未归一化回报时，必须保留尺度系数。

进一步减少精确计算，要找到实际模型中的结构，而不是只辨认方法名称。LQR 用动力学与成本保持二次价值，KL 控制用受限转移和偏离费用使方程换元线性化；递减差分支持单调选择，独立子过程还须配合笛卡尔积动作才能直接分解。它们可以叠加，但动作约束、噪声机制或共享资源的改变也可能破坏原推导，使用时应回到对应条件检查。

资源仍不足时，可以局部搜索，也可以保存可复用的近似价值，二者能在叶值处结合。表 2.14 按输出、模型接口和资源归纳这种选择，并列出应检查的误差依据。深度限制留下尾部误差，有限样本留下期望估计误差，函数表示与拟合留下跨状态误差，动作求解还可能留下选择误差；减小其中一项并不自动减小其他项。

所需输出	模型接口与资源	可用方法	应报告的证书或边界
全状态精确价值／策略	精确期望，可存表并扫描	动态规划、价值或占用 LP	全状态残差、原对偶间隙及恢复条件
特殊结构的反馈律	解析模型，结构满足假设	Riccati、线性换元、阈值或分解	封闭、可稳定、差分或独立性条件
当前状态动作	精确展开，在线时间有限	有限前瞻与滚动规划	截断尾界、叶值误差、根动作与执行损失的区别
当前状态动作	独立生成样本，调用预算有限	稀疏采样、MCTS	查询次数、置信度、叶值与探索条件
可复用的全状态近似	精确或采样模型，价值表过大	聚合、拟合评价、近似策略／价值迭代	一致误差界；若只有加权误差，另需覆盖条件

表 2.14 模型已知时的方法选择。时间与存储应包含预计算、在线求值及模型本身；经验表现不能替代所列条件下的误差保证。

下一章沿用本章的理想 Bellman 算子、评价与改进关系及性能界，却不再默认能够访问准确模型。学习者还要取得数据，从经验估计价值或环境规律，并处理改变策略后数据分布也改变的问题。某些统计分析会单独保留生成模型假设以隔离估计困难，真实在线学习则通常只能沿实际轨迹采集。于是本章的计算误差，将与统计误差、覆盖和探索共同决定能够得到怎样的策略。

第 3 章

未知模型的求解

在导航网格中，智能体执行向右的动作后，可以记录奖励和落脚位置，却未必知道向右成功的概率。第2章的 Bellman 备份需要按转移概率对所有后继状态加权；一次交互只给出一个后果，不能直接提供这个条件期望。本章要解决的正是这一缺口：怎样用交互记录构造价值或策略更新，又怎样选择行动，取得足以支持后续改进的数据？

这里继续假定每一步都能观察马尔可夫状态，经验记为 (s_t, a_t, r_t, s_{t+1})，其中 r_t 是执行 a_t 后收到的奖励。贯穿示例仍采用宽 4、高 3 的网格，起点 $(1,1)$、终点 $(4,3)$、障碍 $(2,2)$；合法意图方向以 0.8 执行，两侧滑移各为 0.1，滑移撞墙则留在原位。进入终点奖励为 1，其他非终止步为 -0.04，终点之后奖励为 0，折扣 $\gamma = 0.9$。后文另设的短链和老虎机会明确说明改动，不能把其手算结果当成整个随机网格的解。

从同一条经验出发，可以直接更新价值，也可以调整策略，还可以先拟合环境模型，再借助预测完成这些更新。表3.1据此固定两个比较问题：改进时是否查询学习模型，执行时动作主要由价值比较或规划产生，还是由参数化策略产生。模型允许重复计算未必再次真实发生的后果，也可能反复放大错误预测；显式策略可免去部署时的动作搜索，却仍需处理梯度估计和访问分布变化。行动者—评论家和深度网络可以服务于不同组合，不能另列成与四种组合互斥的一类。

其中，“基于模型的价值学习”一节把两种做法放在一起讨论：用模型生成经验来更新价值函数，以及在每次执行动作前用模型预测并比较候选动作或轨迹。后一种做法属于在线规划，可以只计算候选轨迹的预计回报，而不训练独立的价值函数。两者都由价值比较或规划结果产生动作；“基于模型的策略优化”一节则讨论如何用模型训练一份参数化策略，供执行时直接调用。

四种组合共同面对图3.1中的问题：经验能否覆盖需要比较的行为，时间抽象是否改变决策间隔，有限数据支持什么保证，以及实验究竟控制了哪些预算。我们会先把这些方法放到可以手算一次更新的尺度，再检查从一次更新走到可靠策略还缺哪些条件。

主要改进接口	是否查询学习模型	价值承担的作用	最终动作来源与例子
无模型价值学习	不查询转移模型	比较动作的长期回报	对 Q 取贪心或探索动作，如 DQN
无模型策略优化	不查询转移模型	基线、优势或行动者的优化目标	参数策略采样或输出动作，如 PPO、SAC
基于模型的价值学习	查询模型以模拟、前瞻或搜索	模拟备份、叶值或候选轨迹评分	对更新后的 Q 或当前规划结果选动作，如 Dyna-Q、MuZero
基于模型的策略优化	查询模型以求导或生成训练经验	给模型内策略训练提供回报与自举	训练后的参数策略，如 PILCO、Dreamer

表 3.1 四种求解组合。分类依据是实际的数据流与动作接口，而不是系统里是否出现过预测网络。

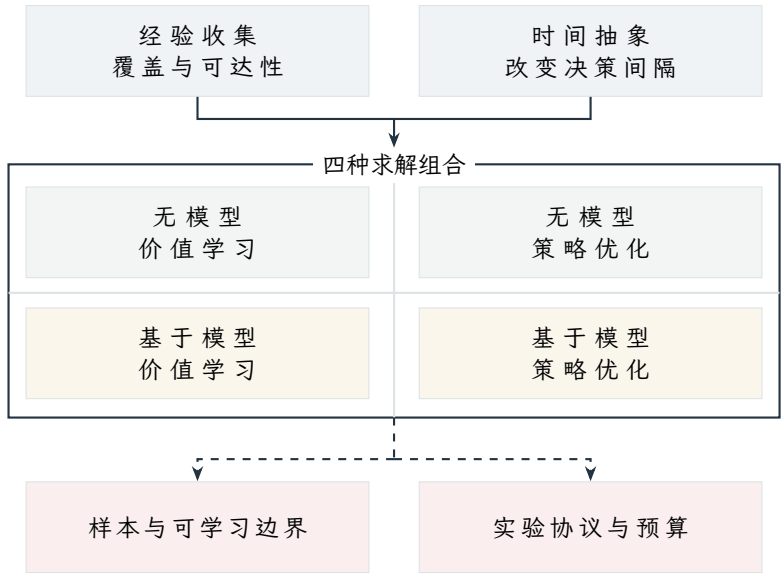


图 3.1 本章的问题关系。实线表示共同输入或组合关系，虚线表示统一的分析与评价口径；四种求解接口没有先后执行关系。

3.1 支持策略改进的经验收集

在网格中，当前策略若一直避开某条岔路，后续训练便不会得到那里的转移和奖励。数据收集因此与策略更新形成反馈：策略决定下一批可见经验，经验又决定下一次策略改进。本节从只影响当前奖励的动作选择开始，分别改变可见信息、奖励规律、输出目标和状态转移，检查每种探索方法究竟在为哪一种改进取得证据。

3.1.1 探索问题中的不确定性与变化维度

网格中从未走过的岔路使我们不知道转移规律；已经走过很多次的岔路则可能仍有随机滑移。前一种困难称为**认知不确定性**（epistemic uncertainty），指现有数据不足以确定规律，增加相关样本可能缩小这种无知。后一种称为**偶然不确定性**（aleatoric uncertainty），指规律本身允许多个随机结果；即使滑移概率完全已知，也不能确定下一次落点。两者对应不同的采样收

改变的条件	决策前可见信息	一次动作提供的样本	典型输出
动作回报未知	动作集合、过去选择与奖励	所选臂的奖励	在线动作序列
上下文出现	本轮特征与过去反馈	当前特征下所选动作的奖励	从特征到动作的策略
奖励由对手选择	历史，可能还有上下文	所选动作的当轮奖励	相对指定比较类的低遗憾序列
只关心部署动作	与随机老虎机相同	可按识别需要分配的奖励样本	一个推荐动作及置信陈述
动作影响状态	当前状态、历史反馈	奖励与后继状态	能到达并利用高价值区域的策略

表 3.2 探索设定的变化维度。表中每行突出一个变化，不表示这些条件互斥。

益：重走岔路可以帮助估计概率，却不会消除滑移。因此，一次罕见结果不足以证明模型仍不了解该处，已有区域的低预测误差也不足以证明重要岔路都已探索。

区分这两种不确定性后，还需要确定未知量和采样目标。只估计各动作的奖励均值，与学习依用户特征选动作的规则，需要不同的共享信息；在线服务与最终只推荐一个动作，也允许不同的试验代价。表3.2把这些变化分开，条件仍可组合，例如可见用户特征的同时，奖励由对手改变。进入 MDP 时新增的则是可达性：本次动作会决定下一次能在什么状态取得信息，而不只是多看到一列特征。

定义 3.1 探索的几种评价对象 累积遗憾度量试验期间相对某个比较策略少获得多少期望回报；**简单遗憾**（simple regret）度量试验结束后推荐动作与最优动作的均值差。**覆盖**描述采集机制能否为需要评价的状态动作提供样本，以及这些样本是否充足。使用共享特征时，还要检查样本能否约束预测所需的特征方向；这里的方向属于特征空间。**最终策略损失**则比较输出策略与参照策略在指定初始分布下的回报。

这些指标评价的时间和对象不同，因而可能冲突。要确认一个略差动作确实略差，算法可能多次试用它：试验期间少拿了奖励，最终却更少推荐错动作。类似地，访问许多与通往终点无关的状态会提高访问种类数，却不一定约束关键岔路的动作价值。判断探索收益时，需要检查新增样本是否减少了目标决策的不确定性，而不能仅看数据数量或多样性。

3.1.2 动作回报未知：随机老虎机中的探索

我们先移除网格的状态转移，让每轮都面对同一组 K 个动作，动作只影响本轮奖励。这就是老虎机中的选臂问题，其中一只“臂”对应一个可试验动作。没有到达状态的困难后，仍然只能看到所选臂的结果：若早期奖励偶然偏低，怎样保证这个动作还有机会被重新评价？

比较试验代价时，用始终选择最高均值动作作为参照。每次选到均值较低的臂，就损失两者的均值差；把这一差距按访问次数累加，得到下面的累积伪遗憾。参照中的最大值遍历全部 K 个臂，追求较高奖励；期望则平均算法随机选臂造成的访问次数，而不把某次奖励噪声本身算成决策错误。

定义 3.2　有界随机老虎机　臂 $a \in \{1, \dots, K\}$ 有固定奖励分布 ν_a，每次拉动得到一个取值于 $[0,1]$ 的独立样本；条件于选臂历史，下一样本仍服从 ν_a。记均值 m_a、最优均值 $m_* = \max_a m_a$、差距 $\Delta_a = m_* - m_a$，以及前 T 轮臂 a 的访问数 $N_a(T)$。累积伪遗憾为

$$\mathcal{R}_T = T m_* - \mathbb{E}\left[\sum_{t=1}^{T} m_{a_t}\right] = \sum_{a=1}^{K} \Delta_a \, \mathbb{E} N_a(T). \tag{3.1}$$

“伪”表示比较的是均值，而不是两条独立随机奖励序列的逐次差。

示例 3.3　一次噪声如何锁住贪心策略　教学设定中，两臂分别为均值 0.7 和 0.4 的伯努利分布。各试一次，恰好观察到 $(0,1)$ 的概率为 $0.3 \times 0.4 = 0.12$。此后纯贪心不再试第一臂，而第二臂的经验均值在任意有限次采样后都严格为正，因为最初的那个 1 仍在样本中。因此第一臂的估计一直停在 0，算法可以永久错选；这不是两个均值太接近，而是未被选择的臂失去了纠错机会。

ε-贪心用显式随机试验打破这种闭环：以概率 $1-\varepsilon_t$ 选当前经验最优臂，以概率 ε_t 均匀试验。若 ε_t 恒为正，次优臂会被持续试用，通常付出线性累积遗憾；若下降过快，早期错误可能不再被纠正。它简单，但没有按每个动作剩余的不确定性分配试验。

置信上界（upper confidence bound, UCB）用当前数据允许的较高均值为动作评分。经验均值相近时，样本少的臂仍可能更好，因而需要更宽的误差区间。记轮 t 前的经验均值为 $\widehat{m}_a(t)$、次数为 $N_a(t)$；未访问臂先各试一次，以免分母为 0。UCB1 随后在全部臂中选择“经验均值加区间半宽”最大的动作：

$$a_t \in \arg\max_a \left\{ \widehat{m}_a(t) + \sqrt{\frac{2 \log t}{N_a(t)}} \right\}. \tag{3.2}$$

均值高带来利用，区间宽带来探索。图3.2左侧的教学快照把半宽简化为 $(0.05, 0.20, 0.12)$，三个均值估计为 $(0.55, 0.48, 0.30)$，因此上界分别为 $(0.60, 0.68, 0.42)$。第二臂的当前均值不是最高，却最值得再查一次；这些示意半宽不是从式(3.2)的某个指定时刻反推的实测数据。

Thompson 采样（Thompson sampling）不固定使用区间上端点，而从未知均值的后验中各抽一个候选值，再选抽样值最大的臂。在所设后验下，一个臂被选中的概率对应它成为最优臂的后验概率。例如伯努利奖励配 Beta(1, 1) 先验，观察 $(1, 0, 1)$ 后，似然 $m^2(1-m)$ 使后验变为 Beta(3, 2)，后验均值为 $3/5$；但选臂用的是本轮抽样值，不是这个均值。若三个抽样值为 $(0.58, 0.63, 0.27)$，就选第二臂。这一解释依赖给定的先验和奖励模型；后验可信区间是否具有频率学覆盖率，仍需另行分析。

UCB1 的一个经典结果能说明探索成本怎样进入式(3.1)。在上述固定、独立、有界奖励条件下，对每个 $\Delta_a > 0$ 的臂，

$$\mathbb{E}N_a(T) \le \frac{8\log T}{\Delta_a^2} + 1 + \frac{\pi^2}{3}, \qquad \mathcal{R}_T \le \sum_{a:\Delta_a>0} \left(\frac{8\log T}{\Delta_a} + \left(1 + \frac{\pi^2}{3}\right)\Delta_a \right). \tag{3.3}$$

这里 π 在常数 $\pi^2/3$ 中是圆周率，不是策略。证明的关键不是直接控制所有动作选择，而是控制错误选择所需的事件：若最优臂没有被低估、次优臂没有被高估，而且次优臂已访问超过 $8\log T/\Delta_a^2$ 次，它的置信上界就不能超过最优臂。Hoeffding 集中不等式限制前两类坏事件；对可能的样本数和轮次求和得到常数项；剩余访问数乘差距便得到遗憾。自适应选臂要求同时控制各个可能的样本数，不能只在最终随机访问数上直接套一次固定样本不等式。上述常数和算法来自 UCB1 原始分析[1]。

[1] P. Auer, N. Cesa-Bianchi, P. Fischer, *Finite-Time Analysis of the Multiarmed Bandit Problem* In Machine Learning, 2002, vol. 47, pp. 235–256

对数代价也有信息论来源。Lai–Robbins 分析考虑满足正则条件的参数化奖励族与一致有效策略，即在该族每个实例上，对任意 $c > 0$ 都有 $\mathcal{R}_T = o(T^c)$。若一个次优臂的分布改成均值超过 m_* 的合法分布，算法必须收集足够样本区分这两个世界；所需次数满足渐近下界

$$\liminf_{T\to\infty} \frac{\mathbb{E}N_a(T)}{\log T} \ge \frac{1}{\inf_{\nu:\,\mathbb{E}_\nu r > m_*} \mathrm{KL}(\nu_a \| \nu)}.$$

分母中的候选 ν 只取所声明奖励族内、均值超过 m_* 的合法分布；下确界选出与当前次优臂最难区分的替代分布。KL 越小，单个样本提供的辨识信息越少，算法就越需要重复试验。例如伯努利族中分母趋于 $\mathrm{kl}(m_a, m_*)$。这是固定分布族内、依赖当前实例的渐近辨识成本，不是任意非平稳奖励下都存在的 $\log T$ 保证[2]。

[2] T. L. Lai, H. Robbins, *Asymptotically Efficient Adaptive Allocation Rules* In Advances in Applied Mathematics, 1985, vol. 6, no. 1, pp. 4–22

3.1.3 反馈条件变化：上下文与对抗老虎机

同一个推荐动作对不同用户可能有不同奖励。若决策前已看到用户特征，为每个动作只存一个全局均值就会忽略这项条件信息。上下文老虎机（contextual bandit）学习根据本轮特征选择动作的规则；上下文就是动作选择前可见的特征。本节仍假定动作不改变下一轮上下文的生成机制，从而将条件奖励预测与 MDP 的状态转移分开。

为了让不同用户和动作共享样本，先假定奖励均值是已知特征的线性函数。动作 a 在轮 t 的特征为 $\boldsymbol{x}_{t,a}\in\mathbb{R}^d$，未知系数为 $\boldsymbol{\theta}_*$。下面第一式规定奖励与噪声的关系，后两式用过去实际选中的特征和奖励计算正则化最小二乘估计：

$$r_t=\boldsymbol{x}_{t,a_t}^{\top}\boldsymbol{\theta}_*+\eta_t,\qquad \boldsymbol{V}_t=\lambda\boldsymbol{I}+\sum_{u<t}\boldsymbol{x}_{u,a_u}\boldsymbol{x}_{u,a_u}^{\top},\quad \widehat{\boldsymbol{\theta}}_t=\boldsymbol{V}_t^{-1}\sum_{u<t}\boldsymbol{x}_{u,a_u}r_u. \tag{3.4}$$

假设特征在选动作前已知、$\|\boldsymbol{x}_{t,a}\|_2\le L$、$\|\boldsymbol{\theta}_*\|_2\le S$，噪声相对于历史条件均值为 0 且为 R-次高斯，正则化 $\lambda>0$。这些条件容许自适应选择特征，但不容许噪声在看到本轮抽样结果后任意配合奖励。

选臂需要知道这份参数估计在当前动作方向上还能错多少，而不只是各坐标的误差。自归一化集中将参数误差与自适应采样得到的 $\boldsymbol{V}_t$ 一起控制，给出形如 $\|\widehat{\boldsymbol{\theta}}_t-\boldsymbol{\theta}_*\|_{\boldsymbol{V}_t}\le\beta_t$ 的高概率椭球，其中 $\|\boldsymbol{z}\|_{\boldsymbol{V}}^2=\boldsymbol{z}^{\top}\boldsymbol{V}\boldsymbol{z}$。对允许失败概率 $\delta\in(0,1)$，一个常用半径是

$$\beta_t=R\sqrt{2\log\frac{\det(\boldsymbol{V}_t)^{1/2}}{\det(\lambda\boldsymbol{I})^{1/2}\delta}}+\sqrt{\lambda}S.$$

在适用的时间一致事件上，这个椭球同时限制各轮参数误差。对某个已知动作特征，我们在椭球内选择预测奖励最高的参数，得到该动作的乐观评分；最大化的对象是尚未被数据排除的参数，而不是任意实向量。利用柯西不等式可得

$$\max_{\|\boldsymbol{\theta}-\widehat{\boldsymbol{\theta}}_t\|_{\boldsymbol{V}_t}\le\beta_t}\boldsymbol{x}_{t,a}^{\top}\boldsymbol{\theta}=\boldsymbol{x}_{t,a}^{\top}\widehat{\boldsymbol{\theta}}_t+\beta_t\sqrt{\boldsymbol{x}_{t,a}^{\top}\boldsymbol{V}_t^{-1}\boldsymbol{x}_{t,a}}.$$

若 $\boldsymbol{V}_t=\operatorname{diag}(4,100)$，沿两个坐标方向的不确定半宽分别为 $0.5\beta_t$ 和 $0.1\beta_t$。多次观察第二个方向不会自动了解与之正交的第一个方向。图3.2右侧示意这种长轴沿信息较少方向展开的关系，轴长不按该数例的比例绘制。

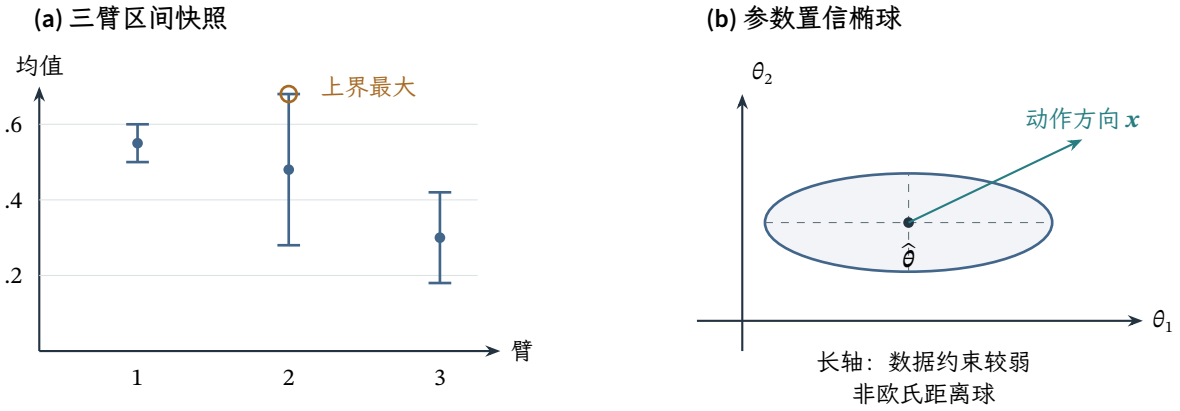


图 3.2 动作区间与参数椭球。左图为明确标注的三臂教学快照，UCB 选择上端点最大的第二臂；右图示意线性参数置信集合，较长的轴对应信息较少的方向。二者都把不确定性转成动作评分，但线性模型还通过共享特征传递信息。

LinUCB 常以这个方向性奖励构造动作评分；OFUL 直接在联合参数置信集合中做乐观选择，并把集合有效性纳入分析[3]。线性 Thompson 采样则抽取整个参数向量，再对所有动作用同一个抽样参数评分。共享的是线性结构和设计矩阵，而不是“把标量 UCB 换成更大网络”就能保留的保证。具体统计结论依赖所用噪声模型、置信半径或抽样尺度。

若奖励规律不固定，每个臂可能根本没有待估计的固定均值。我们改用无上下文的对抗老虎机：对手在本轮实际抽样前选择奖励向量 $\boldsymbol{r}_t \in [0,1]^K$，智能体只看到 r_{t,a_t}。对手可依赖过去历史，却不能在看到本轮动作后临时改写奖励。此时 EXP3 用权重记录各臂迄今的奖励证据，并把权重归一化成抽样概率。为更新未被选臂也有定义的奖励估计，所选臂的奖励除以其抽样概率，其他臂记 0；下面三式依次给出抽样、估计与指数权重更新：

$$p_{t,a} = (1-\varepsilon)\frac{w_{t,a}}{\sum_b w_{t,b}} + \frac{\varepsilon}{K}, \quad \hat{r}_{t,a} = \frac{\mathbf{1}\{a_t = a\} r_{t,a_t}}{p_{t,a}}, \quad w_{t+1,a} = w_{t,a}\exp(\eta \hat{r}_{t,a}) \tag{3.5}$$

估计奖励较高的臂获得更大的下一轮权重。各臂权重从正值开始；$\varepsilon > 0$ 保证所有抽样概率为正，η 与 ε 必须按具体遗憾分析配合，而不能任意取大值。

无偏性的条件可以直接检查。固定抽样前历史及本轮奖励向量后，

$$\mathbb{E}[\hat{r}_{t,a} \mid \text{历史}, \boldsymbol{r}_t] = p_{t,a}\frac{r_{t,a}}{p_{t,a}} = r_{t,a}.$$

概率小会放大方差，但不会在这些条件下改变条件均值。若对手看到 a_t 后才选择 $\boldsymbol{r}_t$，这一步条件化便不成立。通常的外部遗憾比较事后最佳固定臂，而不是每轮都预知奖励的全知动作序列；对抗上下文算法还要明确比较的策略类。EXP3 的原始保证正是围绕这种反馈与比较协议建立的[4]。

[3] Y. Abbasi-Yadkori, D. Pál, C. Szepesvári, *Improved Algorithms for Linear Stochastic Bandits* In Advances in Neural Information Processing Systems, 2011, pp. 2312–2320

[4] P. Auer, N. Cesa-Bianchi, Y. Freund, R. E. Schapire, *The Non-stochastic Multiarmed Bandit Problem* In SIAM Journal on Computing, 2002, vol. 32, no. 1, pp. 48–77

3.1.4 学习目标变化：累积遗憾与最佳臂识别

同样的随机老虎机，若试验期间也要服务用户，就需要控制累积收益损失；若只在试验后部署一个动作，则可以多试当前看来略差的候选，换取更可靠的推荐。后一种任务称为最佳臂识别，评价的是输出而非整段动作序列。预算结束时输出 $\hat{a}_T$，下面分别计算它比最佳均值差多少，以及它落在最优臂集合之外的概率；两者都越小越好：

$$\mathfrak{r}_T = \mathbb{E}[m_* - m_{\hat{a}_T}], \qquad \mathbb{P}\{\hat{a}_T \notin \arg\max_a m_a\}. \tag{3.6}$$

错选一个只差 10^{-4} 的动作，对这两个指标的影响并不相同。仅报告推荐错误率会把近乎无损与严重失误放在同一类别中。表3.3进一步区分何时结束试验：预算耗尽与证据充分，是两种不同的停止依据。

协议	预先固定什么	算法输出与待分析量
固定预算	总拉臂次数 T	推荐 $\hat{a}_T$；分析简单遗憾或错误概率
固定置信度	允许错误 δ，必要时精度 ϵ	随机停止时间 τ 和推荐 $\hat{a}_\tau$；保证错误概率不超过 δ 并分析 $\mathbb{E}\tau$

表 3.3 纯探索的两种协议。固定置信度不是先任意选择预算，再宣称置信度已经满足。

固定置信度协议允许边采样边检查是否停止，因而停止时的样本数由数据决定。只在某个预先固定样本数有效的区间不足以支持这种反复查看。我们给全部臂、全部正整数样本数同时分配失覆盖概率；对 $[0,1]$ 奖励，取下面的半宽与区间：

$$c(n) = \sqrt{\frac{\log(2Kn(n+1)/\delta)}{2n}},$$
$$[L_a(n), U_a(n)] = [\hat{m}_a(n) - c(n), \hat{m}_a(n) + c(n)].$$

Hoeffding 不等式给出单个 (a,n) 的失覆盖概率不超过 $\delta/[Kn(n+1)]$。因为 $\sum_{n\ge1} 1/[n(n+1)] = 1$，联合界保证全部臂、全部样本数同时覆盖的概率至少为 $1-\delta$。这不是最紧的边界，却明确处理了自适应停止。

逐次淘汰（successive elimination）保留尚可能最优的臂；若 $U_a < \max_b L_b$，则淘汰 a。在全部区间覆盖的事件上，真正最优臂不可能满足淘汰条件。教学快照若三个区间为 $[0.55,0.65]$、$[0.40,0.52]$、$[0.42,0.70]$，第二臂可淘汰，第一、第三臂还不能分胜负。LUCB 把试验集中到当前经验最优臂 b 与其余臂中上界最大的竞争者 c[5]。当 $L_b \ge U_c - \epsilon$ 时，可以推荐一个 ϵ-最优臂。这个例子中下一步重点采第一和第三臂，而不是轮流采已排除的第二臂。

[5] S. Kalyanakrishnan, A. Tewari, P. Auer, P. Stone, *PAC Subset Selection in Stochastic Multi-Armed Bandits* In Proceedings of the 29th International Conference on Machine Learning, 2012, pp. 655–662

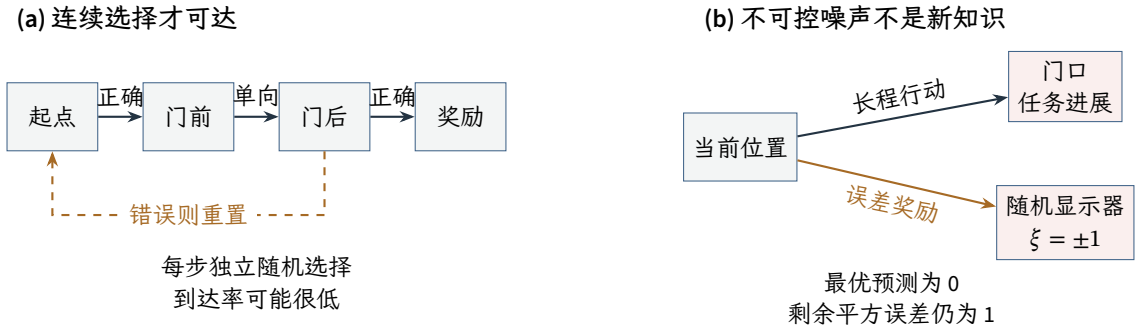


图 3.3 可达性与预测误差的两个教学反例。左侧为从导航任务抽出的确定性单向门链，每一步错误都会重置；右侧的随机显示器可持续制造不可控预测误差，却不帮助通过门口。两者均为明确修改过的独立任务，不是基准网格的新转移规则。

区间正确时，淘汰和停止逻辑便给出正确性；样本复杂度还要分析何时区间足够窄。固定置信度理论进一步研究不同臂之间的最优样本分配[6]。从区间宽度看，为了分开差距 Δ_a，半宽通常要降到 Δ_a 的常数比例，所需样本因而带有 Δ_a^{-2} 量级和置信度对数项，但这一粗略尺度不能给出最优常数。差距趋近 0 会使精确识别越来越昂贵；并列最优时，要求用严格区间分离证明唯一最优可能永不停止，应改用适合并列情形的识别目标，例如允许正精度的 ϵ-最优识别。

[6] E. Kaufmann, O. Cappé, A. Garivier, *On the Complexity of Best-Arm Identification in Multi-Armed Bandit Models* In Journal of Machine Learning Research, 2016, vol. 17, no. 1, pp. 1–42

3.1.5 状态随动作变化：MDP 中的覆盖、可达性与长时程探索

回到 MDP，每轮并不会自动把智能体送回同一组候选动作面前。某扇门只有到达门口才能尝试，一次转向可能让后续奖励区域暂时不可达。图3.3左侧是由网格导航抽出的独立教学链：取消滑移，增设单向门与失败后重置，连续 H 次必要选择才能到达唯一奖励。若每次独立均匀试两个动作，一回合走完全链的概率为 2^{-H}；这个数字描述该随机试验方案，不是所有能观察状态的算法都必须付出的下界。

要探索链末端，当前动作必须能利用“远处尚未确定的收益”这一信息。乐观价值先给未充分访问的状态动作较高估值，再通过 Bellman 备份将它传向上游；模型置信集合则保留尚未被数据排除的转移与奖励，选其中预计回报较高的模型来规划。后验采样强化学习（posterior sampling for reinforcement learning, PSRL）在回合开始抽取一套完整动力学和奖励，再在整回合执行其策略。这样多个时刻共享同一个探索假设，不会像逐步重新随机选方向那样频繁放弃当前路线。后验及其计算仍依赖模型假设，有限样本表格保证将在第3.7节另列条件[7]。

[7] I. Osband, D. Russo, B. Van Roy, *(More) Efficient Reinforcement Learning via Posterior Sampling* In Advances in Neural Information Processing Systems, 2013, pp. 3003–3011

也可以不显式规划一个乐观模型，而在训练奖励中加入鼓励获取新信息的信号。这称为内在奖励（intrinsic reward）：外在任务奖励仍为 r_t，训练使用 $r_t + \beta b_t$，其中 b_t 由采样或预测记录构造，β 决定探索信号的权重。

方法	估计对象与典型信号	怎样改变行为及主要边界
访问计数	$b_t(s,a)=1/\sqrt{N_t(s,a)+1}$	奖励少访问位置；离散计数需要有意义的状态划分
伪计数	用密度模型更新前后的概率变化构造计数替代	将新颖性扩到大状态空间；依赖密度学习假设，不是实际访问次数
ICM	学习特征中的动作条件前向预测误差，配合逆动力学表示	偏向可由动作影响的特征；不能保证剔除所有噪声
RND	可训练预测器与固定随机目标网络的输出差	以拟合困难代表新颖性；泛化、遗忘和观测噪声会影响分数
回合内好奇心	当前嵌入与本回合记忆的距离或近邻密度	鼓励回合内未访区域；跨回合重置记忆改变了“新”的含义

表 3.4 新颖性信号的计算对象。表中的奖励是训练工具，不自动对应环境转移的置信区间。

表3.4比较不同 b_t 的测量对象。加入它会改变训练时的选择偏好，所以评价必须另报不含内在奖励的任务回报，才能确认探索最终帮助了原任务。

按表中的计数公式，同一教学状态的两个动作已访问 99 次和 3 次，探索奖励分别为 0.1 和 0.5；后者因样本更少而得到更高偏好。预测误差却可能在数据充分后仍然很大。设与位置无关的显示器每步独立输出 $\xi_t \in \{-1,1\}$，两值等概率。平方损失下最优预测为 0，剩余期望误差仍是 $\mathbb{E}\xi_t^2=1$。把这项误差奖励给智能体，可能使它停在显示器旁：它已经知道显示规律，却仍能持续获取探索奖励。这就是 noisy-TV 反例，说明不可预测性不能直接当成可通过采样减少的无知。

ICM 在学习到的特征空间预测动作后果，用预测误差提供探索信号；表示的学习目标影响哪些变化会被当成值得探索的后果[8]。

RND 改为预测固定随机网络的输出，避免直接用随机后继的不可预测性作为目标；但其新颖性仍依赖输入表示、预测器训练和数据分布[9]。ICM、RND 与回合记忆分别改变表示、预测目标或比较范围，缓解条件并不相同。

在特别稀疏的任务中，还要区分“发现过某个状态”与“能稳定再到达它”。Go-Explore 保存已发现状态及其到达路径，返回选定状态后继续探索，再处理带执行随机性的稳健复现。模拟器存档恢复提供了普通单轨迹交互没有的访问能力；即使两者都记录一百万步，信息条件也不同。探索性课程可以从更易到达的起点或子目标逐步扩展，但必须说明谁提供重置和任务选择。目标重标记如何把失败轨迹变成其他任务的成功经验，留到第6章讨论[10]。

[8] D. Pathak, P. Agrawal, A. A. Efros, T. Darrell, *Curiosity-Driven Exploration by Self-Supervised Prediction* In Proceedings of the 34th International Conference on Machine Learning, 2017, pp. 2778–2787

[9] Y. Burda, H. Edwards, A. Storkey, O. Klimov, *Exploration by Random Network Distillation* In International Conference on Learning Representations, 2019

[10] A. Ecoffet, J. Huizinga, J. Lehman, K. O. Stanley, J. Clune, *First Return, Then Explore* In Nature, 2021, vol. 590, pp. 580–586

3.2 无模型的价值学习

取得经验后，还需把观察到的奖励和后继变成长期价值估计。第2章的 Bellman 备份计算条件期望；现在只能用样本逼近它。本节先固定产生目

标回报的策略，比较完整回报和自举目标，再根据价值改变行为。这样可以先看清采样与估计误差，随后再处理策略变化和共享参数带来的耦合。

3.2.1 完整回报与一步自举

一条到达终点的轨迹已记录沿途全部奖励，我们可以把某次访问之后的奖励折扣相加，作为该状态的一次价值样本。**蒙特卡罗**（Monte Carlo, MC）评价就用这种完整随机回报修正估值：样本回报高于当前预测时上调，低于预测时下调。设回合在 T 终止，$V(s_T)=0$，目标及更新为

$$G_t=\sum_{j=0}^{T-t-1}\gamma^j r_{t+j},\qquad V(s_t)\leftarrow V(s_t)+\alpha_t[G_t-V(s_t)]. \tag{3.7}$$

首次访问 MC 对每回合第一次出现的状态更新，每次访问 MC 对该状态的所有出现都更新。二者利用的回报都来自真实奖励，但同一回合内重复访问对应的回报并不独立。

示例 3.4　同一终止轨迹上的不同目标　在基准随机网格中，一条可能的轨迹依次经过

$$(1,1),(1,1),(2,1),(3,1),(4,1),(4,2),(4,3).$$

第一次向右时向下滑移撞墙，因此留在原位；其后五步实现意图方向。奖励为五个 -0.04 和末步的 1。于是起点两次访问的回报分别为

$$G_0=-0.04\frac{1-0.9^5}{1-0.9}+0.9^5=0.426686,$$
$$G_1=-0.04\frac{1-0.9^4}{1-0.9}+0.9^4=0.51854.$$

只看这一回合，首次访问样本是 0.426686，每次访问的样本平均为 0.472613。它们都是该轨迹产生的估计，不是起点的精确策略价值。若冻结估值 $V(1,1)=0.2$、$V(2,1)=0.3$，前两次 TD 目标却分别是 $-0.04+0.9(0.2)=0.14$ 和 $-0.04+0.9(0.3)=0.23$。取步长 0.5，第一条 TD 更新把起点估值从 0.2 改为 0.17；从相同初值做首次访问 MC 则得到 0.313343。这里为了比较目标没有把各方法串行混用。

若回合很长，等待完整回报会推迟更新；继续任务甚至没有自然的回合终点。Bellman 关系提供了另一种目标：把已观察的一步奖励与下一状态的当前估值相加。**时序差分**（temporal difference, TD）用这个目标与当前预测的差立即更新，δ_t 就是这次样本的预测差：

$$\delta_t=r_t+\gamma V(s_{t+1})-V(s_t),\qquad V(s_t)\leftarrow V(s_t)+\alpha_t\delta_t. \tag{3.8}$$

这种用已有预测构造新目标的做法称为**自举**（bootstrapping）。终止转移的下一价值是 0；继续任务的人工时间截断则不能一概置 0。表3.5把目标的偏差来源与更新时机分开，避免把一步目标尚不准确误解为最终估计必然有偏。

比较对象	MC	TD(0)
更新何时可得	等实际回报完成	观察一步转移即可
随机性来源	之后整段奖励和状态	当步奖励、后继状态及当前估值
对初值的依赖	初值不进入回报目标	后继估值进入目标
目标的条件均值	固定策略完整回报对应 V^π	对应 $T^\pi V$，通常不等于 V^π
适用注意	需终止或处理无限回报尾项	需控制自举与采样条件

表 3.5 目标偏差不等于最终估计偏差。TD 目标含当前估值，不妨碍满足条件的表格迭代最终收敛到真实价值。

固定策略时，对给定 $s_t = s$ 的动作、奖励和后继取平均，TD 误差的条件均值为 $(T^\pi V)(s) - V(s)$。因此，样本更新虽然有噪声，平均方向仍指向 Bellman 固定点。在有限折扣 MDP 中，若奖励二阶矩受控、策略固定、每个需要评价的状态被无限访问，且各状态的访问步长满足 $\sum_n \alpha_n(s) = \infty$、$\sum_n \alpha_n(s)^2 < \infty$，配合相应马尔可夫噪声条件，可用随机逼近证明表格 TD 收敛。步长和发散使初始误差有机会被持续修正，平方和收敛则限制噪声的长期影响；Bellman 压缩性确定唯一平衡点。这不覆盖任意常数步长或任意函数逼近。

MC 的一致性则直接来自回报平均：独立回合的首次访问回报可用大数定律，每次访问版本要处理回合内依赖和访问次数的随机性。无限时域折扣 MC 若只截取有限长度，还留下尾项偏差。MC 与 TD 都依赖数据条件，但依赖的方式不同[11]。

[11] R. S. Sutton, A. G. Barto, *Reinforcement Learning: An Introduction*, MIT Press, 2018, 2nd ed.

3.2.2 多步回报、资格迹与时间信用

MC 一直使用真实奖励直到终点，TD(0) 在一步之后就接入预测。若奖励需要多步才能传回当前状态，可以先观察 n 步奖励，再用第 n 步的估值补上余下未来。对固定估值 V 和终止时刻 T，令 $m = T - t$，允许长度 $1 \le n \le m$，得到

$$G_t^{[n]} = \sum_{j=0}^{n-1} \gamma^j r_{t+j} + \gamma^n V(s_{t+n}), \qquad V(s_T) = 0. \tag{3.9}$$

方括号 $[n]$ 表示目标长度，不是参数迭代。n 增大让奖励影响更快传过多步，但也把更多未来随机性带入一次目标。

λ 回报（lambda return）用一组几何权重混合这些长度，不再只选一个 n。参数 λ 越大，越多权重交给较长的真实奖励段。对 $0 \le \lambda \le 1$，混合目标为

$$G_t^{\lambda} = (1-\lambda)\sum_{n=1}^{m-1} \lambda^{n-1} G_t^{[n]} + \lambda^{m-1} G_t^{[m]}. \tag{3.10}$$

末项收走所有剩余权重，故权重之和为 1；$\lambda = 0$ 得到一步目标，$\lambda = 1$ 得到完整回报。若采样片段只是截断而非终止，末端 V 必须保留。

上述计算从一次访问出发，把后续奖励组合成它的更新目标，称为前向视图。完整的 λ 回报需要等到后续奖励出现才能算出。若希望每收到一个 TD 误差就立即利用它，可以反过来保存过去访问的影响：每次访问加入当前价值对参数的梯度，旧的梯度贡献则逐步衰减。这份累积记录称为**资格迹**（eligibility trace）；当前 TD 误差乘以资格迹，就能同时修正与过去访问有关的参数，这称为后向视图。下面在有限终止轨迹上冻结参数，证明两种方式累计的更新相同。比较截断片段上的前后向计算时，也必须采用相同的末端自举值。

定理 3.5　固定参数下前后向更新等价　在一条有限终止轨迹上固定可微函数 V_θ 及参数 θ，定义 $\delta_k = r_k + \gamma V_\theta(s_{k+1}) - V_\theta(s_k)$。从 $\boldsymbol{e}_{-1} = \mathbf{0}$ 递推积累资格迹

$$\boldsymbol{e}_k = \gamma\lambda \boldsymbol{e}_{k-1} + \nabla_\theta V_\theta(s_k).$$

若整回合结束后一次性应用更新，则

$$\sum_{t=0}^{T-1} (G_t^{\lambda} - V_\theta(s_t)) \nabla_\theta V_\theta(s_t) = \sum_{k=0}^{T-1} \delta_k \boldsymbol{e}_k. \tag{3.11}$$

证明　先对 n 步目标作望远镜展开：

$$G_t^{[n]} - V(s_t) = \sum_{j=0}^{n-1} \gamma^j [r_{t+j} + \gamma V(s_{t+j+1}) - V(s_{t+j})] = \sum_{j=0}^{n-1} \gamma^j \delta_{t+j}.$$

在式(3.10)中，δ_{t+j} 出现在所有 $n \ge j+1$ 的项内。它的总系数为

$$\gamma^j \left[(1-\lambda) \sum_{n=j+1}^{m-1} \lambda^{n-1} + \lambda^{m-1} \right] = (\gamma\lambda)^j.$$

端点 $\lambda = 0, 1$ 可直接代入定义验证。因此 $G_t^{\lambda} - V(s_t) = \sum_{k=t}^{T-1} (\gamma\lambda)^{k-t} \delta_k$。交换有限和得到

$$\sum_{t=0}^{T-1} \sum_{k=t}^{T-1} (\gamma\lambda)^{k-t} \delta_k \nabla V(s_t) = \sum_{k=0}^{T-1} \delta_k \sum_{t=0}^{k} (\gamma\lambda)^{k-t} \nabla V(s_t).$$

方法	改变什么	需要保留的边界
积累迹	每次访问都加上特征，旧迹乘 $\gamma\lambda$	重复访问会累加；等价定理使用固定参数
替换迹	表格或二值特征中，把本次激活分量置 1 而非继续累加	改变重复访问权重；一般稠密特征不能照搬“置 1”语义
真实在线 TD	使用修正的迹与更新，匹配随时间变化的前向目标	经典精确等价针对线性表示的在线前向视图，不是任意网络的代数恒等式
奖励重分配	把延迟奖励分配到预测中关键的过去事件	保持目标须保证逐轨迹折扣总和相等，或明确等价条件

表 3.6 改变信用传播与改变奖励位置并非同一操作。真实在线 TD 修正参数变化引起的偏差，RUDDER 类方法则学习奖励应归到哪些事件。

> 内层和正是递推定义的 $\boldsymbol{e}_k$，故两种总更新相同。 ■

若 $\gamma = 0.9$、$\lambda = 0.8$，资格迹对当前、前一次和前两次访问的梯度贡献分别赋予权重 $1, 0.72, 0.5184$，见图3.4。当前误差因而可以影响较早的预测，无须等待回合结束。但上一定理的等价性限定了固定参数；每步更新参数后，过去目标和梯度都可能改变。表3.6据此区分改变迹、修正在线更新和重分配奖励三类操作。

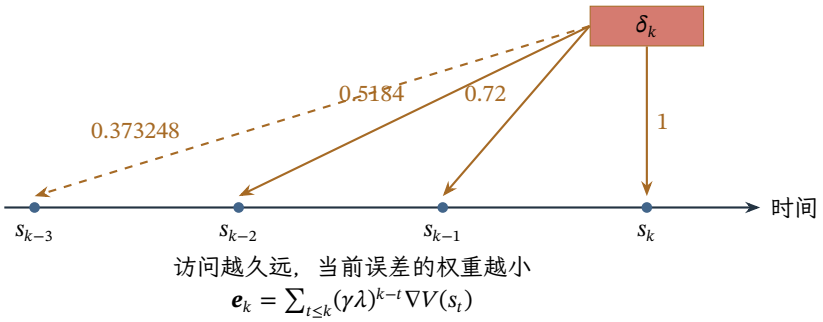


图 3.4 同一个 TD 误差的后向信用分配。横轴为访问时刻，箭头上的数值来自 $\gamma\lambda = 0.72$。前向视图把未来误差加给当前状态，后向视图在误差出现时按资格迹更新与过去访问有关的参数。

真实在线 TD 的修正正是为了让在线参数变化也有明确的前向解释[12]。

RUDDER 利用序列回报预测，把预测变化归给较早的关键事件[13]。在有限回合、未折扣回报下，重分配若满足 $\sum_t \tilde{r}_t = \sum_t r_t$，就保留逐轨迹总回报；折扣目标则需要 $\sum_t \gamma^t \tilde{r}_t = \sum_t \gamma^t r_t$，不能只核对未加权总和。预测不完整时还要有残差补偿或另外分析误差。即使奖励位置改得很合适，从未到达过奖励区域的数据也不能凭空告诉模型那里有什么。

[13] J. A. Arjona-Medina, M. Gillhofer, M. Widrich, T. Unterthiner, J. Brandstetter, S. Hochreiter, *RUDDER: Return Decomposition for Delayed Rewards* In Advances in Neural Information Processing Systems, 2019

3.2.3 离策略回报估计与校正

策略改进后，回放中的旧轨迹仍可利用，但直接平均其回报会评价收集数据的旧策略，而非当前目标策略。我们将前者称为行为策略 μ，后者称为目标策略 π。两者共享环境时，轨迹概率的差别来自动作抽样；重要性校正按这一概率比重新加权，使行为数据可用于目标评价。前提是目标可能产生的轨迹在行为分布下也有机会出现，否则任何权重都无法补出缺失经验。

定理 3.6　轨迹与逐决策重要性校正　考虑有限时域 H，固定行为策略 μ 与目标策略 π，二者共享初始分布和环境核。设目标轨迹分布对行为轨迹分布绝对连续，且每步奖励满足 $\mathbb{E}_\pi|r_t| < \infty$，$0 \le t < H$。记

$$\rho_t = \frac{\pi(a_t \mid s_t)}{\mu(a_t \mid s_t)}, \qquad W_{u:v} = \prod_{k=u}^{v} \rho_k .$$

则

$$\mathbb{E}_\pi G_0 = \mathbb{E}_\mu[W_{0:H-1} G_0] = \mathbb{E}_\mu\left[\sum_{t=0}^{H-1} \gamma^t W_{0:t} r_t\right]. \tag{3.12}$$

证明　对轨迹 $\tau = (s_0, a_0, r_0, \dots, s_H)$，共同的初始分布和联合转移奖励核给出

$$p_\pi(\tau) = \rho_0(s_0) \prod_{t=0}^{H-1} \pi(a_t \mid s_t) p(s_{t+1}, r_t \mid s_t, a_t).$$

在行为分布支持上，$p_\pi(\tau)/p_\mu(\tau) = W_{0:H-1}$，共同环境项全部消去。对轨迹求和或积分便得到第一个等式；绝对连续性保证没有目标质量遗漏在分母为 0 的地方。

再把轨迹截到 r_t, s_{t+1}，记此前缀为 $\tau_{0:t+1}$。对剩余轨迹积分后，两条策略的前缀分布仍由相同环境核与各自动作概率相乘得到，故前缀密度比为 $W_{0:t}$。完整轨迹的绝对连续性也保证前缀绝对连续。将换测度分别用于非负的 $|r_t|$，得到

$$\mathbb{E}_\mu[W_{0:H-1}|r_t|] = \mathbb{E}_\mu[W_{0:t}|r_t|] = \mathbb{E}_\pi|r_t| < \infty.$$

因而下面各项期望均存在。由于 r_t 仅依赖该前缀，

$$\mathbb{E}_{\mu}[W_{0:H-1} r_t] = \mathbb{E}_{\pi}[r_t] = \mathbb{E}_{\mu}[W_{0:t} r_t].$$

对有限个奖励项加权求和，得到逐决策形式。这个前缀论证不要求在目标概率为 0 的行为历史上，未来概率比也具有条件均值 1。 ■

以网格中一段两步动作前缀为例，若行为动作概率分别为 $1/2, 1/4$，目标概率分别为 $0.8, 0.6$，则比率为 $1.6, 2.4$，乘积为 3.84。对应奖励对逐决策估计的贡献为 $1.6 r_0 + 0.9(3.84) r_1$。概率比不含滑移概率，因为两条策略共享同一转移核；若数据来自另一种滑移机制，这个消去理由便不存在。

方差问题在最简单的教学模型中就会出现：目标策略必选的两步动作，在行为策略下每步概率都是 0.1，故该前缀仅以 0.01 发生，权重为 100。设仅成功前缀末端奖励为 1，其余为 0 且暂取 $\gamma = 1$，无偏估计量以概率 0.01 取 100，否则取 0，均值为 1 而方差为 99。图3.5把低概率和大权重画在同一条路径上。若行为概率改成 0，权重技巧就完全失效。

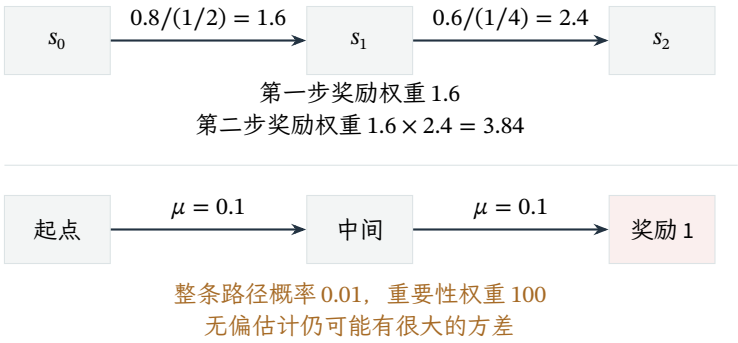


图 3.5 两步重要性权重的乘积。上方为可手算的网格动作前缀，下方为独立的罕见路径教学例；共同环境核不进入比率。宽支持是可校正的前提，大权重则是方差问题。

完整概率比积可能随时域增长而剧烈波动。多步自举可以改为传播逐步 Bellman 误差，并限制较远误差的权重，但是否保留目标策略取决于截断位置。先固定 π，在后继状态对其合法动作按概率求平均，构造

$$\delta_t^{\pi} = r_t + \gamma \sum_{a} \pi(a \mid s_{t+1}) Q(s_{t+1}, a) - Q(s_t, a_t).$$

Retrace 使用 $c_t = \lambda \min(1, \rho_t)$，从给定 (s_t, a_t) 构造

$$Q_{\mathrm{ret},t} = Q(s_t, a_t) + \sum_{k=t}^{T-1} \gamma^{k-t} \left(\prod_{j=t+1}^{k} c_j \right) \delta_k^{\pi}. \tag{3.13}$$

校正方法	权重放在哪里	目标与固定点
普通重要性采样	完整回报或每步奖励前乘概率比积	支持充分时无偏评价 π；方差可能指数增长
直接截断总权重	用 $\min(c, W)$ 替代 W	一般改变期望；没有补偿不能声称仍精确评价 π
Tree Backup	多步误差迹用 $\lambda\pi(a_t \mid s_t)$	以 π 期望备份，保留 Q^π 固定点；未选分支由估值补足
Retrace	迹用 $\lambda \min(1, \rho_t)$	表格、覆盖等条件下固定点为 Q^π，截断并非直接截回报权重
V-trace	TD 误差前用截断 ρ，后续迹另截断 c	有限 $\bar{\rho}$ 一般评价 $\pi_{\bar{\rho}}(a \mid s) \propto \min(\bar{\rho}\mu(a \mid s), \pi(a \mid s))$；$c$ 主要改变传播与收敛速度

表 3.7 几种离策略多步目标的差别。表格固定点结论不能直接替代有限数据和非线性优化分析。

空积为 1。注意第一项误差不乘 ρ_t，因为这里评价的起始动作已给定；π 期望进入每个 Bellman 误差，截断系数只控制更远误差的传播。教学例若 $\delta_t^\pi = 0.4$、$\delta_{t+1}^\pi = -0.2$、$\lambda = 0.8$、$\rho_{t+1} = 2$，则增量为 $0.4 + 0.9(0.8)(-0.2) = 0.256$。以步长 0.5 更新时，起始 Q 增加 0.128。表3.7比较不同方法的截断位置，尤其要看当前误差与后续迹是否承担不同权重。

在 $Q = Q^\pi$ 时，给定每个被访问状态动作，δ_t^π 的条件均值为 0；可预测的迹系数不改变这个零点，这是理解 Retrace 固定点的入口。证明其收缩与控制性质还要利用系数范围和覆盖条件[14]。

V-trace 截断当前误差的概率比则会改变条件动作权重，因此具有不同的有效目标策略[15]。两者不能统称为“截断只降方差、不改目标”。

[14] R. Munos, T. Stepleton, A. Harutyunyan, M. G. Bellemare, *Safe and Efficient Off-Policy Reinforcement Learning* In Advances in Neural Information Processing Systems, 2016

[15] L. Espeholt, H. Soyer, R. Munos, K. Simonyan, V. Mnih, T. Ward, Y. Doron, V. Firoiu, T. Harley, I. Dunning, S. Legg, K. Kavukcuoglu, *IMPALA: Scalable Distributed Deep-RL with Importance Weighted Actor-Learner Architectures* In Proceedings of the 35th International Conference on Machine Learning, 2018, pp. 1407–1416

3.2.4 表格与平均奖励条件下的价值控制

固定策略评价给出当前走法的长期回报，控制则用这个评价改变走法。MC 控制先用完整回报估计 $Q^\pi(s, a)$，再提高当前贪心动作的选择概率；下一批轨迹于是来自改进后的策略。未访问表项仍没有纠错样本。探索起点允许从不同状态动作开始，是额外的数据访问机制；软策略在可达状态给各动作保留正概率，却不能让不可达状态自动出现。采用哪种机制都还要检查实际覆盖。

一步控制保留统一的更新外形

$$Q(s_t, a_t) \leftarrow Q(s_t, a_t) + \alpha_t[y_t - Q(s_t, a_t)], \tag{3.14}$$

区别在目标 y_t，具体见表3.8。SARSA 把下一次实际选择的动作接上去，因此五元组 $(s_t, a_t, r_t, s_{t+1}, a_{t+1})$ 构成更新；Expected SARSA 对目标策略的下一动作求期望；Q-learning 直接用下一状态的最大估值。

方法	目标 y_t	下一动作由谁决定
MC 控制	G_t	整段轨迹中的行为策略，策略改进发生在回报估计之后
SARSA	$r_t + \gamma Q(s_{t+1}, a_{t+1})$	当前行为策略实际抽样；同策略版本评价含探索的行为
Expected SARSA	$r_t + \gamma \sum_a \pi(a \mid s_{t+1}) Q(s_{t+1}, a)$	显式指定目标策略 π；$\pi = \mu$ 时同策略
Q-learning	$r_t + \gamma \max_a Q(s_{t+1}, a)$	目标贪心策略；行为可以继续探索

表 3.8 控制更新中的动作来源。终止转移的自举部分均为 0；所有最大化都只在合法动作集合中进行。

示例 3.7 一条转移，三个一步目标 基准网格中从 $(3,1)$ 向右并到达 $(4,1)$，奖励为 -0.04。教学估值取 $Q((4,1), \text{上}) = 0.8$、$Q((4,1), \text{左}) = 0.2$，行为概率分别为 $0.75, 0.25$，下一次恰好选了左。则 SARSA 目标为 0.14，Expected SARSA 目标为 $-0.04 + 0.9(0.75 \times 0.8 + 0.25 \times 0.2) = 0.545$，Q-learning 目标为 0.68。若当前被更新表项为 0.3、步长为 0.5，新值分别为 $0.22, 0.4225, 0.49$。这些差异来自目标策略和动作抽样，不是对同一个目标做出了三个互相矛盾的估计。

最大化还会偏爱正的估计噪声。独立教学例中，两个动作的真实值均为 0，各估计独立等概率取 -1 或 1；最大值以概率 $3/4$ 为 1、$1/4$ 为 -1，均值为 0.5。这不是某个动作本来更好，而是“选最大”与“报告它的估值”使用了同一份噪声。

要减少这项选择偏差，可以用一份估计选动作，用另一份估计评价被选动作。Double Q-learning 维护两张表 Q^A, Q^B，随机更新其中一张；更新 A 时先在合法动作中最大化 Q^A，再把所选动作的 Q^B 值接到奖励后：

$$a^\star = \arg\max_a Q^A(s_{t+1}, a), \qquad y_t^A = r_t + \gamma Q^B(s_{t+1}, a^\star), \tag{3.15}$$

更新 B 时交换两者角色。行为可对两表之和采用 ε-贪心。在刚才的理想独立噪声例中，用 A 选择、用独立的 B 评价，被选动作的 B 估值条件均值仍为 0。但真实两张表共享环境数据，不保证独立，也可能产生低估或其他逼近误差；双估计针对的是选择与评价耦合，而不是通用误差消除器[16]。

[16] H. van Hasselt, *Double Q-Learning* In Advances in Neural Information Processing Systems, 2010, pp. 2613–2621

表格折扣 Q-learning 的经典收敛结论要求有限状态动作、有界奖励，每个状态动作被无限访问，并且对每一对 (s,a) 的本地更新步长满足

$$\sum_n \alpha_n(s,a) = \infty, \qquad \sum_n \alpha_n(s,a)^2 < \infty.$$

条件期望更新是 $T^*Q - Q$，最优 Bellman 算子的压缩性控制估值误差，随机逼近处理采样噪声。单条持续轨迹若进了无法返回的区域，即使每一步都探索，也未必满足无限访问条件。SARSA 控制还需行为逐渐成为贪心且

仍无限探索，通常称为 GLIE；持续固定 ε 的 SARSA 并非同一个最优性结论[17,18]。

有些任务关心长期每步产出，而不是折扣总和。例如持续运行的服务系统没有自然终点。此时要显式更换目标。对固定策略 π，若有限链不可约并具有适当回返性质，可定义与起点无关的**平均奖励增益**

$$g^{\pi} = \lim_{T\to\infty} \frac{1}{T} \mathbb{E}_{\pi} \sum_{t=0}^{T-1} r_t .$$

对应的**差分价值**衡量相对于长期平均水平的暂时盈亏，满足 Poisson 方程

$$g^{\pi} + h^{\pi}(s) = R^{\pi}(s) + \sum_{s'} P^{\pi}(s' \mid s) h^{\pi}(s'). \tag{3.16}$$

不可约、非周期的有限链可用中心化回报极限定义 h^{π}；更一般单链任务要额外处理瞬态状态与极限形式。因为 $h^{\pi} + c$ 仍是解，需设 $h^{\pi}(s_{\mathrm{ref}}) = 0$ 或令平稳均值为 0 来固定常数。

差分 SARSA 把一步误差改为

$$\delta_t = r_t - \widehat{g} + q(s_{t+1}, a_{t+1}) - q(s_t, a_t),$$
$$q(s_t, a_t) \leftarrow q(s_t, a_t) + \alpha_t \delta_t, \qquad \widehat{g} \leftarrow \widehat{g} + \beta_t \delta_t .$$

差分 Q-learning 以 $\max_a q(s_{t+1}, a)$ 替代下一实际动作值，并配合增益更新及归一化。R-learning 的经典形式也维护差分动作值和平均奖励，但增益只在规定的贪心更新条件下调整[19]。典型增益误差是 $r_t + \max_a q(s_{t+1}, a) - \max_a q(s_t, a) - \widehat{g}$。名称相近不表示更新条件完全相同。

可证明的平均奖励算法还要列明弱连通或单链条件、参考函数、步长及访问要求[20]。式(3.16)没有折扣压缩因子，不能照搬 Q-learning 的折扣证明。

3.2.5 函数逼近下的价值学习与稳定性

网格中的状态可以逐个存表，图像或连续状态则难以枚举。函数逼近（function approximation）改用同一组参数表示许多状态的价值：在线性表示 $V_{\theta}(s) = \boldsymbol{\phi}(s)^{\top}\boldsymbol{\theta}$ 中，已知特征 $\boldsymbol{\phi}(s)$ 决定各参数怎样影响该状态。共享参数使一条经验也能改变未访问状态的预测，同时让不同状态的更新相互牵连。换成网络进一步扩大函数类，却不会自动保留表格更新的压缩结构。

先固定策略 π 和采样分布 d，暂设所讨论的有限状态上 $d(s) > 0$，令 $\boldsymbol{D}$ 为以 $d(s)$ 作对角元的矩阵。这里的 d 是指定的误差权重，不一定等于策略的折扣占用 d^{π}。为避免把“误差小”混成一个目标，需要区分表3.9中的三

[17] C. J. C. H. Watkins, P. Dayan, *Q-Learning* In Machine Learning, 1992, vol. 8, pp. 279–292

[18] S. Singh, T. Jaakkola, M. L. Littman, C. Szepesvári, *Convergence Results for Single-Step On-Policy Reinforcement-Learning Algorithms* In Machine Learning, 2000, vol. 38, pp. 287–308

[19] A. Schwartz, *A Reinforcement Learning Method for Maximizing Undiscounted Rewards* In Proceedings of the Tenth International Conference on Machine Learning, 1993, pp. 298–305

[20] Y. Wan, A. Naik, R. S. Sutton, *Learning and Planning in Average-Reward Markov Decision Processes* In Proceedings of the 38th International Conference on Machine Learning, 2021, pp. 10653–10662

误差目标	公式	需要知道或估计什么
均方价值误差	$\|V_\theta - V^\pi\|_d^2$	真实价值 V^π，通常不能直接监督
均方 Bellman 误差（MSBE）	$\|T^\pi V_\theta - V_\theta\|_d^2$	先对奖励和后继求条件期望，再平方
均方投影 Bellman 误差（MSPBE）	$\|\Pi_d T^\pi V_\theta - V_\theta\|_d^2$	投影后的备份；依赖特征空间和采样权重

表 3.9 固定策略下的三种误差。把样本 TD 误差平方，并不会自动得到其中的 MSBE。

种量。这里 T^π 含真正的环境条件期望，Π_d 是到线性特征空间的 d 加权正交投影；非线性函数类的投影未必唯一，也不能直接沿用后面的矩阵式。

同一个状态可能出现多个随机后继。将每次样本误差平方后平均，与先平均误差再平方，是两个不同的计算；前者还惩罚后继随机性造成的波动。下面的条件方差分解说明为什么这种差异甚至会改变最优参数。

定理 3.8 样本平方误差的条件方差分解 令 x 为计算 Bellman 期望时固定的条件：评价状态价值时取 $x = s$，评价动作价值时取 $x = (s, a)$。设 δ_θ 为二阶可积的样本 TD 误差，则

$$\mathbb{E}[\delta_\theta^2 \mid x] = \big(\mathbb{E}[\delta_\theta \mid x]\big)^2 + \mathrm{Var}(\delta_\theta \mid x). \tag{3.17}$$

方差项可以依赖参数，故两个平方目标的最小化解一般不同。

证明 记 $m_\theta(x) = \mathbb{E}[\delta_\theta \mid x]$，展开 $\delta_\theta^2 = (\delta_\theta - m_\theta)^2 + 2m_\theta(\delta_\theta - m_\theta) + m_\theta^2$。给定 x 取期望，交叉项为 0，第一项就是条件方差，得到结论。 ■

示例 3.9 两个后继使最优参数改变 这是独立于基准网格的单参数教学例：在固定状态 s，奖励为 1、$\gamma = 1/2$，下一状态等概率为 u, v；令 $V_\theta(s) = \theta$、$V_\theta(u) = 0$、$V_\theta(v) = 2\theta$，只在 s 处度量 Bellman 残差。两种样本 TD 误差为 $1 - \theta$ 和 1。因此

$$\big(\mathbb{E}\delta_\theta\big)^2 = (1 - \theta/2)^2, \qquad \mathbb{E}\delta_\theta^2 = \tfrac{1}{2}(1 - \theta)^2 + \tfrac{1}{2}.$$

前者在 $\theta = 2$ 最小，后者在 $\theta = 1$ 最小；差值为 $\theta^2/4$，正是依赖参数的条件方差。在 $\theta = 2$ 处 Bellman 平均残差已经为 0，样本平方损失却仍会把参数往回推。这比仅展示一项常数噪声更直接地说明了目标不等价。

若目标确实是减少 Bellman 条件均值残差，就需要对 MSBE 本身求导，而不能直接把样本平方损失的梯度当作它。将 MSBE 乘 1/2 只消去平方求

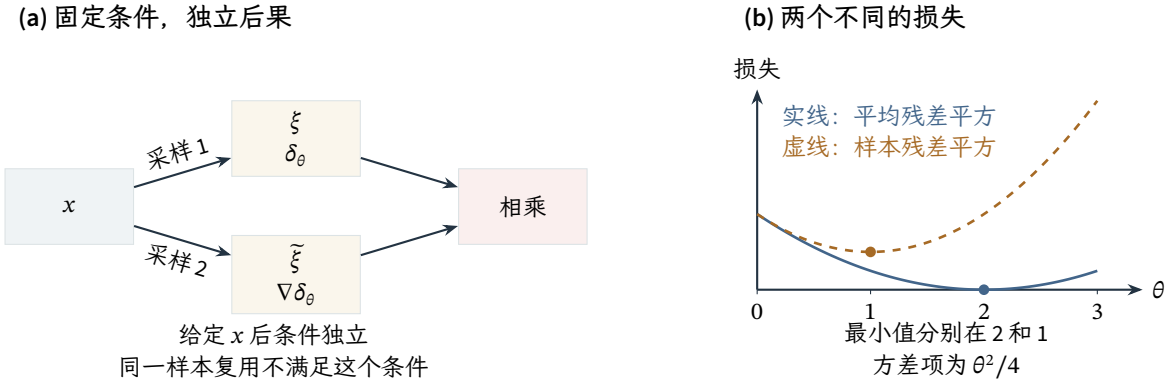


图 3.6 双重采样针对条件均值乘积。左侧两条独立支路保持同一个条件变量 x；右侧曲线按示例3.9的解析公式绘制，展示两个损失的最小值不在同一参数处。

导中的系数 2，不改变最小化方向。沿用 $m_\theta(x) = \mathbb{E}[\delta_\theta \mid x]$，若可交换求导与条件期望，则

$$\nabla_\theta \frac{1}{2}\mathbb{E}_x[m_\theta(x)^2] = \mathbb{E}_x[\mathbb{E}(\delta_\theta \mid x)\,\mathbb{E}(\nabla_\theta \delta_\theta \mid x)]. \tag{3.18}$$

关键是两个条件均值的乘积。用同一后继样本估计两因子，会得到 $\mathbb{E}[\delta_\theta \nabla \delta_\theta \mid x]$，多出两因子的条件协方差；在可微条件下也可看成条件方差梯度的一半。

双重采样要求给定同一个 x 后，独立抽两份后果 $\xi, \tilde{\xi}$，用 $\delta_\theta(x,\xi)\nabla\delta_\theta(x,\tilde{\xi})$ 估计该乘积。图3.6强调两条支路必须条件独立，而不是从回放中随意取两个不同状态。对状态价值，固定 s 后还要独立按 π 抽动作和后果；对动作价值，固定 (s,a) 后独立抽奖励、后继及目标所需随机量。普通在线轨迹通常不能要求环境从原状态再独立执行一次；确定性后继、可查询生成模型或某些特殊结构须单独判断[21]。

常见的半梯度 TD 采取另一条路线：对自举目标停止求导，只执行

$$\theta \leftarrow \theta + \alpha\delta_\theta \nabla_\theta V_\theta(s).$$

“半”表示没有求目标中下一价值对参数的导数。它不是式(3.18)的随机梯度，因而不能借用该损失下降作为稳定性证明。在线性、同策略且采样权重与策略平稳分布匹配时，可用投影 Bellman 方程分析；离策略权重会破坏这条论证。表3.10把这种逐步递推与批量方程、重复回归放在同一个评价或控制接口下比较。

[21] Y. Zhu, L. Ying, *Borrowing From the Future: An Attempt to Address Double Sampling* In Proceedings of The First Mathematical and Scientific Machine Learning Conference, 2020, pp. 246–268

方法	解什么问题	表示、数据和边界
半梯度 TD	用样本逼近 Bellman 固定点，不对目标求全导数	线性同策略有专门保证；一般网络不是某个 MSBE 的下降法
LSTD	解 $\boldsymbol{A}\theta = \boldsymbol{b}$，其中 $\boldsymbol{A} = \mathbb{E}[\boldsymbol{\phi}(\boldsymbol{\phi} - \gamma\boldsymbol{\phi}')^\top]$、$\boldsymbol{b} = \mathbb{E}[r\boldsymbol{\phi}]$	固定策略线性评价；离策略版本需概率比等校正与矩阵可解条件
LSPI	交替做动作值的 LSTD 评价与贪心改进	线性动作特征、固定批数据反复用于不同策略；需要相关状态动作覆盖
拟合 Q 迭代（FQI）	冻结旧 Q，回归 $r + \gamma \max_a Q_{\text{old}}(s', a)$	可用非线性回归器；控制误差包含回归误差、函数类封闭性与分布迁移

表 3.10　评价、控制与求解方式的差别。批量最小二乘减少逐步更新噪声，不会消除数据缺失或错误目标。

LSTD 直接估计线性固定点方程的矩阵与向量，再求解参数[22]。它省去逐步梯度迭代，但样本矩阵病态时仍需正则化和数值诊断，不能把可写成线性方程理解为总能稳定求逆。

LSPI 把这种评价接口接到策略迭代：评价当前策略，按动作值改进，再重新构造与新策略相应的评价方程。其数据复用依赖行为数据对所需状态动作的覆盖，不是一次解线性方程便得到全局最优策略[23]。

FQI 则冻结上一轮动作值，将新的 Bellman 目标交给监督回归器。它允许树模型等非梯度回归工具；每轮拟合误差以及从数据分布到策略访问分布的迁移，仍会影响最终控制质量。三者提供了不同计算接口，不能只按是否使用梯度分类[24]。

一个完全线性的反例足以说明离策略、自举与共享参数同时出现的风险。Baird 反例有 7 个状态、8 个参数，奖励全为 0，$\gamma = 0.99$[25]。目标策略总选实线动作，转到状态 7；行为策略以 $1/7$ 选实线动作，以 $6/7$ 选虚线动作，后者均匀转到上方 6 个状态。行为链的平稳分布为均匀分布。特征取

$$\boldsymbol{\phi}(i) = \frac{2\boldsymbol{e}_i + \boldsymbol{e}_8}{\sqrt{5}} \quad (1 \le i \le 6), \qquad \boldsymbol{\phi}(7) = \frac{\boldsymbol{e}_7 + 2\boldsymbol{e}_8}{\sqrt{5}}.$$

令 $\boldsymbol{\Phi}$ 的第 i 行为 $\boldsymbol{\phi}(i)^\top$，$\boldsymbol{D} = \boldsymbol{I}/7$，$\boldsymbol{P}^\pi = \mathbf{1}\boldsymbol{e}_7^\top$。对带一步重要性比的半梯度 TD，固定当前参数、按行为平稳样本取期望，漂移为

$$\mathbb{E}[\Delta\theta \mid \theta] = \alpha\boldsymbol{M}\theta, \qquad \boldsymbol{M} = \boldsymbol{\Phi}^\top\boldsymbol{D}(\gamma\boldsymbol{P}^\pi - \boldsymbol{I})\boldsymbol{\Phi}. \tag{3.19}$$

重要性比修正了给定状态的动作分布，却没有把行为状态权重 $\boldsymbol{D}$ 换成目标状态权重。

在不变的对称子空间 $\theta_1 = \cdots = \theta_6 = a$、$\theta_7 = b$、$\theta_8 = c$ 中，该漂移作用为

$$\begin{pmatrix} \dot{a} \\ \dot{b} \\ \dot{c} \end{pmatrix} = \frac{1}{35}\begin{pmatrix} -4 & 1.98 & 1.96 \\ 0 & -0.01 & -0.02 \\ -12 & 5.92 & 5.84 \end{pmatrix}\begin{pmatrix} a \\ b \\ c \end{pmatrix}. \tag{3.20}$$

[22] S. J. Bradtke, A. G. Barto, *Linear Least-Squares Algorithms for Temporal Difference Learning* In Machine Learning, 1996, vol. 22, pp. 33–57

[23] M. G. Lagoudakis, R. Parr, *Least-Squares Policy Iteration* In Journal of Machine Learning Research, 2003, vol. 4, pp. 1107–1149

[24] D. Ernst, P. Geurts, L. Wehenkel, *Tree-Based Batch Mode Reinforcement Learning* In Journal of Machine Learning Research, 2005, vol. 6, pp. 503–556

[25] L. Baird, *Residual Algorithms: Reinforcement Learning with Function Approximation* In Proceedings of the Twelfth International Conference on Machine Learning, 1995, pp. 30–37

未除 35 的矩阵具有特征多项式 $z(z^2 - 1.83z + 0.26)$，因此漂移特征值为 0、约 0.04785009 和 0.00443562。例如较大的正特征值对应 $(a, b, c) \approx (0.34124745, -0.01187117, 1)$。若用期望更新作确定性迭代，沿这个方向每步乘 $1 + \alpha(0.04785009) > 1$；在对应平均常微分方程中则指数增长。即使采用趋零且和发散的正步长，该方向的乘积仍不衰减。由此看到的是平均动力学的不稳定方向，而不只是某次随机运行的波动；随机更新还需相应随机逼近分析，不能把独立平稳样本的期望等式不加说明地当成任意相关轨迹下的参数均值递推。真实价值是 0，函数类完全能表示它，问题出在更新动力学。

上述反例中，真实零价值在函数类内，平均更新仍有发散方向；单靠表示能力无法修复它。梯度 TD 方法为固定策略的线性评价改造目标和递推。先在行为平稳采样下定义校正后的固定点矩阵 $\boldsymbol{A}$、奖励向量 $\boldsymbol{b}$ 及特征二阶矩 $\boldsymbol{C}$：

$$\boldsymbol{A} = \mathbb{E}_{\mu}[\rho_t \boldsymbol{\phi}_t (\boldsymbol{\phi}_t - \gamma \boldsymbol{\phi}_{t+1})^{\top}], \quad \boldsymbol{b} = \mathbb{E}_{\mu}[\rho_t r_t \boldsymbol{\phi}_t], \quad \boldsymbol{C} = \mathbb{E}_{\mu}[\boldsymbol{\phi}_t \boldsymbol{\phi}_t^{\top}].$$

若 $\boldsymbol{C}$ 正定，则 MSPBE 为 $(\boldsymbol{b} - \boldsymbol{A}\theta)^{\top} \boldsymbol{C}^{-1} (\boldsymbol{b} - \boldsymbol{A}\theta)$。GTD2 用辅助向量 $\boldsymbol{w}$ 跟踪 $\boldsymbol{C}^{-1}(\boldsymbol{b} - \boldsymbol{A}\theta)$，例如双时间尺度更新

$$\begin{aligned} \boldsymbol{w} &\leftarrow \boldsymbol{w} + \beta_t [\rho_t \delta_t - \boldsymbol{\phi}_t^{\top} \boldsymbol{w}] \boldsymbol{\phi}_t, \\ \theta &\leftarrow \theta + \alpha_t \rho_t (\boldsymbol{\phi}_t - \gamma \boldsymbol{\phi}_{t+1}) (\boldsymbol{\phi}_t^{\top} \boldsymbol{w}). \end{aligned} \tag{3.21}$$

辅助变量把难以直接估计的期望乘积拆成两个受控的递推，快变量在慢变量变化之前近似跟踪所需均值。

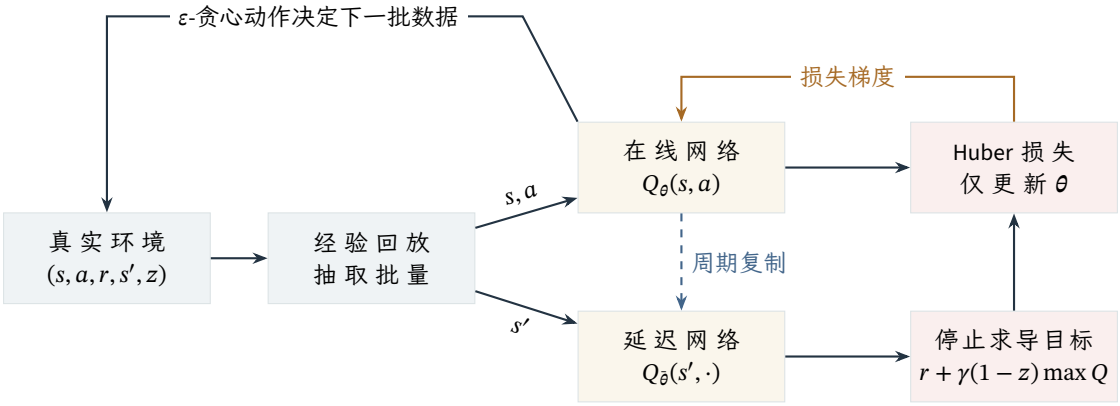


图 3.7 DQN 的数据与参数流。真实转移写入回放，在线网络给出被选动作的估值，延迟网络构造下一状态目标；虚线表示周期复制参数，不是通过目标分支回传损失梯度。

GTD 早期版本以期望 TD 更新的平方范数为目标；GTD2 针对 MSPBE；TDC 采用 TD 加校正的形式，在同一线性目标下组织更新；emphatic TD 则通过跟随迹重设状态权重，例如 $F_t = i_t + \gamma\rho_{t-1}F_{t-1}$ 中 i_t 指定关注程度，以改变离策略投影的稳定性条件。它们并非都在优化同一个无权 Bellman 残差。收敛定理还需固定策略、特征与重要性比的矩条件、行为链覆盖、矩阵条件以及合适步长；双时间尺度分析常要求 $\alpha_t/\beta_t \to 0$。这些评价结论没有直接证明深度控制稳定[26,27]。

3.2.6 深度价值控制的训练机制

用网络 $Q_\theta(s,a)$ 代替表格后，同一组参数同时决定当前预测和下一状态目标。连续采样又使相邻经验高度相关，少数极端 TD 误差还可能主导一次梯度。DQN 把真实经验存入回放、用延迟参数生成目标，并限制大误差的梯度幅度，分别应对这三个训练问题。它们改变的是样本组织和短期回归过程，不是任意网络的收敛证明。

每次训练从回放分布 $\mathcal{D}$ 取记录 (s,a,r,s',z)，其中 $z=1$ 仅表示环境真正终止。我们要减小在线网络对记录动作的预测与停止求导目标的差；目标先在 s' 的合法动作中找最高延迟估值，再加已观察奖励。记在线参数 θ、延迟参数 $\bar\theta$，得到

$$y = r + \gamma(1-z)\max_{a'\in\mathcal{A}(s')} Q_{\bar\theta}(s',a'), \qquad L(\theta) = \mathbb{E}_{\mathcal{D}}\ell_\kappa\big(y - Q_\theta(s,a)\big), \tag{3.22}$$

其中 $\ell_\kappa(u) = u^2/2$ 当 $|u|\le\kappa$，否则为 $\kappa(|u|-\kappa/2)$。这个 Huber 形式使大误差的导数限幅。y 在该次更新中停止求导，目标网络不从这条损失直接反向传播。图3.7把两条参数路径分开。

[26] R. S. Sutton, H. R. Maei, D. Precup, S. Bhatnagar, D. Silver, C. Szepesvári, E. Wiewiora, *Fast Gradient-Descent Methods for Temporal-Difference Learning with Linear Function Approximation* In Proceedings of the 26th Annual International Conference on Machine Learning, 2009, pp. 993–1000

[27] R. S. Sutton, A. R. Mahmood, M. White, *An Emphatic Approach to the Problem of Off-Policy Temporal-Difference Learning* In Journal of Machine Learning Research, 2016, vol. 17, no. 73, pp. 1–29

算法 3.1 包含数据收集的 DQN 循环

输入： 网络 θ、空回放 $\mathcal{D}$、批量大小 B、目标同步间隔 C、更新频率、合法动作接口

置 $\bar{\theta} \leftarrow \theta$，从环境获得起始状态 s
for 每个真实环境步 t **do**
  用当前 Q_θ 的 ε_t-贪心策略在 $\mathcal{A}(s)$ 中选择 a
  执行 a，观察 r, s' 及真正终止标记 z，将 (s, a, r, s', z) 写入 $\mathcal{D}$
  if 已满足回放预热数量且到达更新时刻 **then**
    均匀抽取 B 条记录，按式(3.22)计算停止求导的目标 y_i
    对 $B^{-1}\sum_i \ell_\kappa(y_i - Q_\theta(s_i, a_i))$ 做规定次数梯度更新
  end if
  if 目标网络更新计数达到 C **then**
    $\bar{\theta} \leftarrow \theta$，重置同步计数
  end if
  若真正终止或环境因时间上限要求重置，则重置并取得新起点；否则令 $s \leftarrow s'$
  仅时间截断的记录仍令 $z = 0$，并保留重置前的 s' 用于自举
end for

输出： 在线网络及与训练探索策略区分的评估策略

算法3.1中的 C 按环境步还是梯度步计数必须在实现中固定。取示例3.7的一条记录，若延迟网络最大值为 0.8、在线被选动作值为 0.3，则 $y = 0.68$、残差为 0.38。当 $\kappa = 1$，对该输出的梯度为 -0.38；在仅这一标量可训练、学习率 0.1 的教学网络中，新输出为 0.338。真实共享网络还会改变其他状态动作，不能把这个标量更新当作一般网络输出的精确变化。

原始 DQN 在 Atari 像素输入、固定动作重复与预处理协议下检验了上述机制[28]。回放减少相邻样本在同一批中的相关性，也允许同一真实经验参与多次更新；这不等于新增了独立环境信息。目标网络固定一个短期回归目标，但同步时目标仍会改变。奖励裁剪也改变了训练目标，不能把所有具体设计视为任何任务都适用的定理。

后续部件针对不同的误差来源。表3.11保留每项实际改变的公式，便于区分表示改造、抽样改变与目标改变。

Double DQN 在目标中分开动作选择与评价，避免同一次最大化总是同时选中偏高噪声。在线网络与目标网络仍共享训练历史，因此这不是两个独立无偏估计器，改动也不自动消除所有过估计[29]。

Dueling 用均值中心化消除 V 与 A 任意加减常数的代数歧义，使不同动作能够共享状态评价。但中心化后的 A 不必等于某个给定策略的真实优势；它首先是网络分解中的一个参数化量[30]。

[28] V. Mnih, K. Kavukcuoglu, D. Silver, A. A. Rusu, J. Veness, M. G. Bellemare, A. Graves, M. Riedmiller, A. K. Fidjeland, G. Ostrovski, S. Petersen, C. Beattie, A. Sadik, I. Antonoglou, H. King, D. Kumaran, D. Wierstra, S. Legg, D. Hassabis, *Human-Level Control through Deep Reinforcement Learning* In Nature, 2015, vol. 518, pp. 529–533

[29] H. van Hasselt, A. Guez, D. Silver, *Deep Reinforcement Learning with Double Q-Learning* In Proceedings of the AAAI Conference on Artificial Intelligence, 2016, pp. 2094–2100

[30] Z. Wang, T. Schaul, M. Hessel, H. van Hasselt, M. Lanctot, N. de Freitas, *Dueling Network Architectures for Deep Reinforcement Learning* In Proceedings of the 33rd International Conference on Machine Learning, 2016, pp. 1995–2003

部件	机制或公式	不能由它推出什么
Double DQN	在线网络选 $a^\star = \arg\max_a Q_\theta(s', a)$，延迟网络评价 $Q_{\bar\theta}(s', a^\star)$	两个网络仍相关，不能保证完全无偏
Dueling 结构	$Q(s,a) = V(s) + A(s,a) - \lvert\mathcal{A}(s)\rvert^{-1}\sum_b A(s,b)$	分解改善共享表示，不代表学到了独立可识别的真实优势
优先回放	$P(i) \propto (\lvert\delta_i\rvert + \epsilon)^p$，权重 $w_i \propto (NP(i))^{-\beta}$	非均匀抽样改变损失权重；$\beta < 1$ 通常只作部分校正
NoisyNet	权重写成 $\boldsymbol{W} = \boldsymbol{M} + \boldsymbol{\Sigma} \odot \boldsymbol{E}$，学习噪声尺度	参数噪声与逐步随机动作不同，不自动保证长程覆盖

表 3.11 深度价值学习中的四种机制。它们分别改变目标、表示、数据抽样和探索参数，不能只用“更稳定”概括。

优先回放若以固定缓冲区的均匀经验损失为目标，取 $\beta = 1$ 并保留正确的 $1/(NP(i))$ 因子，可以对当前抽样分布校正；常见的批内最大值归一化、过期优先级和逐渐增加 β 都需要单独说明[31]。

[31] T. Schaul, J. Quan, I. Antonoglou, D. Silver, *Prioritized Experience Replay* In International Conference on Learning Representations, 2016

NoisyNet 把可学习噪声加入网络参数，一次参数扰动会同时影响多个动作评分，其作用范围不同于逐步 ε 随机动作[32]。噪声采样频率和尺度学习规则决定探索的时间相关性，但参数随机并不自动保证访问到远处关键状态。

组合系统必须用受控消融解释。Rainbow 在 57 个 ALE 游戏、2 亿帧训练的具体配置中，逐一去掉 Double、优先回放、dueling、多步、分布式目标和参数噪声等组件；论文中的优先回放与多步移除影响较大，Double 与 dueling 对中位汇总的影响较小且依游戏而异。这是已组合系统内的条件贡献，不是组件在所有任务上的独立效应。其评估每隔一百万环境步进行一次，并使用最好快照，还涉及 no-op 和 human-starts 协议；因此不能把报告值当作预先约定最终检查点的无选择偏差估计[33]。

Agent57 进一步结合内外在价值、跨时间尺度策略族、回合级元控制器及更长的序列训练。它回答的是更强探索与记忆如何组成系统，不是与 Rainbow 使用相同总预算的一次单因素试验。把论文中的表现差异归因于某一个部件，必须先统一交互、网络、回放与评估口径；无法统一时，只陈述各自协议下的证据。需要历史信息的 DRQN 与 R2D2 将在第4章讨论，不能把信息不足简单归为网络太小[34]。

[32] M. Fortunato, M. G. Azar, B. Piot, J. Menick, I. Osband, A. Graves, V. Mnih, R. Munos, D. Hassabis, O. Pietquin, C. Blundell, S. Legg, *Noisy Networks for Exploration* In International Conference on Learning Representations, 2018

[33] M. Hessel, J. Modayil, H. van Hasselt, T. Schaul, G. Ostrovski, W. Dabney, D. Horgan, B. Piot, M. G. Azar, D. Silver, *Rainbow: Combining Improvements in Deep Reinforcement Learning* In Proceedings of the AAAI Conference on Artificial Intelligence, 2018, pp. 3215–3222

[34] A. P. Badia, B. Piot, S. Kapturowski, P. Sprechmann, A. Vitvitskyi, Z. D. Guo, C. Blundell, *Agent57: Outperforming the Atari Human Benchmark* In Proceedings of the 37th International Conference on Machine Learning, 2020, pp. 507–517

3.2.7 回报分布与控制充分表示

两个动作的期望回报相同，实际后果仍可能很不同。在独立教学例中，路径 A 总回报恒为 0.5，路径 B 等概率得到 -0.5 或 1.5；均值均为 0.5，但只有 B 会出现较低和较高的结果。只存一个均值无法保留这项区别。这里另设了奖励分布，并不声称基准网格存在这两条精确路径；图3.8展示的就是这两个指定分布。

令 $Z^\pi(s,a)$ 为给定状态动作之后的随机折扣回报。**分布式价值学习**（distributional value learning）学习的是整个回报分布，而非仅其均值。分布 Bellman 关系为

$$Z^\pi(s,a) \overset{D}{=} r+\gamma Z^\pi(s',a'), \qquad (s',r)\sim p(\cdot,\cdot\mid s,a), \quad a'\sim\pi(\cdot\mid s'). \tag{3.23}$$

右侧的未来随机回报按给定 s',a' 的条件分布抽取，不能误把它理解成一条确定性递推。

C51 把质量放在固定支撑点 $z_1,\dots,z_N$ 上，学习各点概率；Bellman 变换后的原子 $r+\gamma z_j$ 要按距离插值投影回固定支撑，支撑范围之外的质量会被截到端点。QR-DQN 反过来固定每个原子的概率 $1/N$，学习分位位置 $\theta_i(s,a)$；IQN 以随机分位水平 τ 作为网络输入，表示一个条件分位函数。这三个表示对支撑范围、分辨率和采样方式的限制不同。

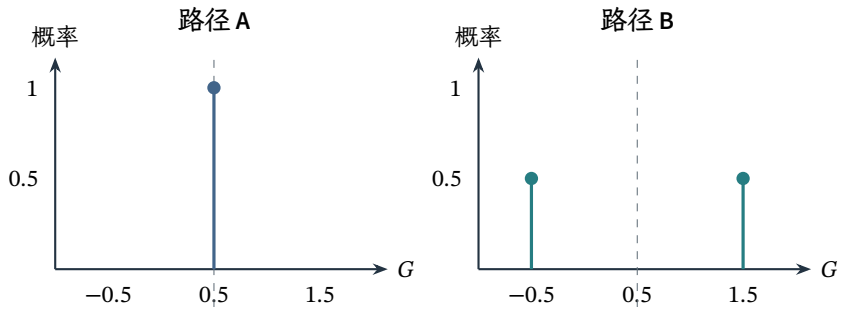


图 3.8 相同期望不意味着相同回报分布。两图为人工指定的离散分布，虚线均位于期望 0.5；这里的不确定性是回报本身的随机性，不是估计参数的置信区间。

要学习分位位置，需要让高分位输出对正残差比负残差更敏感，而不是像平方回归那样都追向均值。以分位回归为例，令 $\tau_i = (i-\frac{1}{2})/N$，$a^\star$ 是在后继合法动作中按估计均值选出的贪心动作，目标样本为 $z'_j = r+\gamma\theta_j(s', a^\star)$。对 $u = z'_j - \theta_i(s,a)$，将 Huber 误差按分位水平非对称加权，再对全部 N^2 对输出和目标平均：

$$\rho^\kappa_{\tau_i}(u) = |\tau_i - \mathbf{1}\{u<0\}|\frac{\ell_\kappa(u)}{\kappa}, \qquad L = \frac{1}{N^2}\sum_{i,j}\rho^\kappa_{\tau_i}(z'_j - \theta_i).$$

正负残差具有不对称权重，才能把某个输出拉到指定分位，而不是全拉向均值。例如 $\tau_i = 0.75$、$u = 0.4$、$\kappa = 1$ 时损失为 $0.75(0.4^2/2) = 0.06$；同样大小的负残差只乘 0.25。若去掉这种不对称，分位语义就消失了[35,36,37]。

在固定策略、$1 \le p < \infty$ 且 p 阶矩有界的条件下，对分布族采用状态动作上的最大 p-Wasserstein 距离，分布 Bellman 算子是 γ 压缩：耦合相同的一步奖励与后继后，未来差异被 γ 缩小，再对条件分布积分即可。控制时依据均值取最大动作，动作切换会破坏直接沿用这一论证的条件。即使完整学到 Z^π，若仍按期望最大化，也没有自动引入风险厌恶；风险目标将在第8章另定。回报分布同样不能自动表示“这条分布是用多少样本估出来的”。

回报表示保留了一个状态动作的结果分布，状态表示则决定哪些不同状态可共用预测。合并状态时，至少要避免把奖励或未来决策机会不同的状态当成同一个。设映射 $f : \mathcal{S} \to \bar{\mathcal{S}}$；具有同一像的状态构成一个等价类。若合并状态对相同合法动作有相同奖励均值，且进入每个等价类 C 的概率也相同，即

$$\sum_{s'\in C} P(s' \mid s_1, a) = \sum_{s'\in C} P(s' \mid s_2, a),$$

那么 Bellman 备份可以在等价类上闭合。这是双模拟的重要条件；MDP 同态还可以包含状态相关的动作映射。价值等价则只要求对指定策略与价值

[35] M. G. Bellemare, W. Dabney, R. Munos, *A Distributional Perspective on Reinforcement Learning* In Proceedings of the 34th International Conference on Machine Learning, 2017, pp. 449–458

[36] W. Dabney, M. Rowland, M. G. Bellemare, R. Munos, *Distributional Reinforcement Learning with Quantile Regression* In Proceedings of the AAAI Conference on Artificial Intelligence, 2018, pp. 5779–5786

[37] W. Dabney, G. Ostrovski, D. Silver, R. Munos, *Implicit Quantile Networks for Distributional Reinforcement Learning* In Proceedings of the 35th International Conference on Machine Learning, 2018, pp. 1096–1105

表示方法	监督信号	希望保留的性质及边界
DeepMDP	潜在转移与奖励预测损失	在相应误差、距离和光滑条件下连接价值；有限训练损失不等于满足全局条件
CURL	同一观测不同增强的对比目标	提高表示一致性；正样本增强必须不抹掉动作所需信息
SPR	动作条件多步潜在预测与目标表示匹配	保留时间与动作相关结构；预测存在不代表执行时查询模型规划
DrQ	对增强观测计算并正则化价值学习目标	用合理增强约束价值一致性；不是环境转移模型

表 3.12 辅助表示目标与控制接口。理想结构保证、训练损失和实际测试表现应分别陈述。

测试函数保留相关备份，不一定保留全部观测或完整转移分布，必须说明测试类有多大。

另设一个只提供局部图像的导航例：两个视觉几乎相同的走廊端点，一个只能向上绕过障碍，另一个向下才接近终点。若编码器只看局部纹理并把它们合并，同一个潜在状态就无法同时给出正确动作。这个反例改变了基准网格的地图与观测接口；它说明局部图像未必能替代马尔可夫状态。相反，两个外观不同但奖励和后继等价类完全相同的状态可以在控制上等价。像素重建相似与控制充分性不是同一判据[38]。

价值等价进一步围绕所需策略与价值测试函数定义模型要保留的内容。缩小测试集合可以降低学习要求，却也缩小了结论范围；不能在一个策略集合上检验等价后，直接推广到任意后续搜索和任务[39]。

表3.12沿监督信号比较几种表示方法。要从辅助目标走到控制结论，还应检查它是否保留了动作后果，而不只看特征是否易于预测。

[38] R. Givan, T. Dean, M. Greig, *Equivalence Notions and Model Minimization in Markov Decision Processes* In Artificial Intelligence, 2003, vol. 147, no. 1–2, pp. 163–223

[39] C. Grimm, A. Barreto, S. Singh, D. Silver, *The Value Equivalence Principle for Model-Based Reinforcement Learning* In Advances in Neural Information Processing Systems, 2020, pp. 5541–5552

DeepMDP 把奖励与潜在转移预测联系到价值误差；相关条件针对指定距离、误差和光滑性，不是仅凭训练集重建分数判断表示充分[40]。

CURL 用同一观测的不同增强构造正样本，使表示在这些变化下保持一致。增强若抹去了与动作后果有关的信息，对比目标做得好反而可能使控制更难，因此增强设计也是任务假设[41]。

SPR 用动作条件的多步预测约束表示，使潜在特征保留部分时间关系。辅助预测不意味着执行时一定查询它作规划；分类仍应看策略改进实际使用的信息流[42]。

DrQ 把图像增强接到价值目标与评价中，通过共享训练数据的不同视图约束估计。它改变的是数据与正则化接口，不要求学习一个可滚动的环境转移模型[43]。

3.2.8 价值误差与策略性能

估值是否有用，最终取决于它选出的动作能取得多少回报。下面先假定每个合法状态动作的估计都与 Q^* 相差至多 ϵ，据此控制贪心策略的损失；这里的无穷范数取遍全部合法状态动作，而非只平均训练样本。这个较强条件避免了关键岔路被平均权重掩盖，也让选错动作的代价可以逐步累加。

定理 3.10　动作价值误差到贪心策略损失　在有限折扣 MDP 中，若 $\|q - Q^*\|_\infty \le \epsilon$，$\pi_q$ 在每个状态选择 q 的最大合法动作，则

$$\|V^* - V^{\pi_q}\|_\infty \le \frac{2\epsilon}{1-\gamma}. \tag{3.24}$$

证明　固定 s，令 $a^* \in \arg\max_a Q^*(s,a)$、$a_q = \pi_q(s)$。由贪心性 $q(s,a_q) \ge q(s,a^*)$，

$$Q^*(s,a^*) - Q^*(s,a_q) \le [Q^*(s,a^*) - q(s,a^*)] + [q(s,a_q) - Q^*(s,a_q)] \le 2\epsilon.$$

又因 $Q^*(s,a_q) = R(s,a_q) + \gamma \mathbb{E}[V^*(s') \mid s,a_q]$，

$$V^*(s) - V^{\pi_q}(s) \le 2\epsilon + \gamma \mathbb{E}[V^*(s') - V^{\pi_q}(s') \mid s,a_q].$$

沿 π_q 展开 n 步，右边为 $2\epsilon \sum_{t=0}^{n-1} \gamma^t$ 加上 $\gamma^n \mathbb{E}[V^*(s_n) - V^{\pi_q}(s_n)]$。有限折扣任务价值有界，尾项随 $n \to \infty$ 消失，得到逐状态上界，再取无穷范数。 ■

两次误差分别对应高估被选动作和低估真正最优动作，$1/(1-\gamma)$ 则来自沿途重复作出次优选择。这也解释了为什么不能把“某批数据上的均方

[40] C. Gelada, S. Kumar, J. Buckman, O. Nachum, M. G. Bellemare, *DeepMDP: Learning Continuous Latent Space Models for Representation Learning* In Proceedings of the 36th International Conference on Machine Learning, 2019, pp. 2170–2179

[41] M. Laskin, A. Srinivas, P. Abbeel, *CURL: Contrastive Unsupervised Representations for Reinforcement Learning* In Proceedings of the 37th International Conference on Machine Learning, 2020, pp. 5639–5650

[42] M. Schwarzer, A. Anand, R. Goel, R. D. Hjelm, A. Courville, P. Bachman, *Data-Efficient Reinforcement Learning with Self-Predictive Representations* In International Conference on Learning Representations, 2021

[43] I. Kostrikov, D. Yarats, R. Fergus, *Image Augmentation Is All You Need: Regularizing Deep Reinforcement Learning from Pixels* In International Conference on Learning Representations, 2021

已知误差	如何选动作	相应结论或限制
$\|q - Q^*\|_\infty \le \epsilon$	直接最大化 $q(s,a)$	最优性能损失至多 $2\epsilon/(1-\gamma)$
$\|v - V^*\|_\infty \le \epsilon$	用准确模型最大化 $R + \gamma P v$	与规划章相同的 $2\gamma\epsilon/(1-\gamma)$ 界；多一个 γ 来自一次前瞻
$\|q - Q^\pi\|_\infty \le \epsilon$	对当前策略的近似评价作贪心改进	支持相对 π 的近似改进分析，不是相对 Q^* 的同一界
训练分布均方误差较小	取决于部署访问状态	还需覆盖、分布比或其他误差转移条件

表 3.13 动作值和状态值的用途差异。状态值本身不能在未知模型中完成一步动作比较。

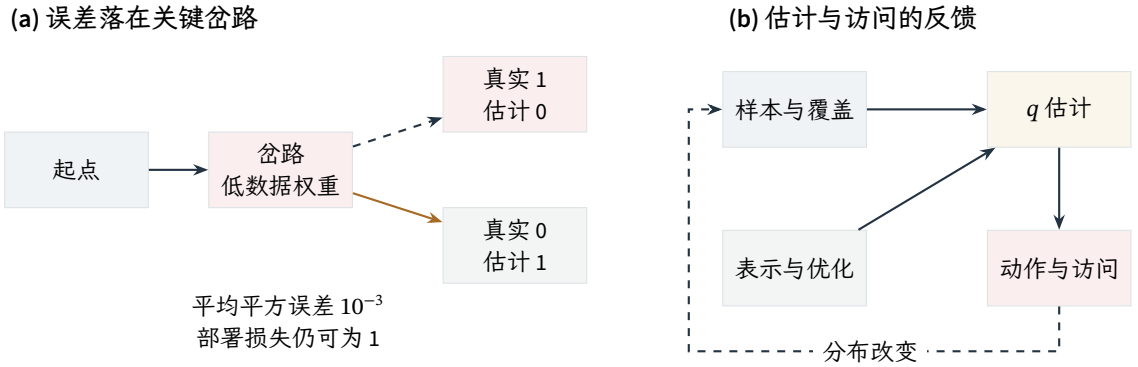


图 3.9 局部错误与整体行为。左侧为人工指定的岔路反例，右侧区分表示、样本、优化及分布转移误差；图中的箭头是因果接口，不声称这些误差可以不加条件地线性相加。

误差很低”直接代入定理。表3.13将这一结论与状态值前瞻及当前策略评价并列，关键区别在误差究竟相对谁定义。

考虑从网格岔路抽出的独立终止决策例：到岔路必选左或右，真实回报分别为 1 和 0；数据分布却只有 10^{-3} 质量落在这两个动作上，其余状态估计完全准确。若 q 在岔路把两值颠倒，则训练均方误差仅为 10^{-3}，部署损失却为 1。图3.9左侧显示错误集中位置，右侧串起误差来源。数据中“少见”不能替代任务中“不重要”。

表示误差决定函数类能否同时容纳关键区别，样本误差决定有限观测能否辨清回报，优化误差决定训练是否找到所要求的解；部署策略又可能访问训练中罕见的区域。这些环节必须分别检查。下一节改变主要优化对象，直接更新策略参数，但评论家误差与数据覆盖并不会因此消失。

3.3 无模型的策略优化

连续控制力有无穷多取值，难以像表格动作那样逐个比较；即使只有上下左右，贪心动作也可能在估值稍有变化时突然切换。若希望直接调整控制输出或平滑改变动作概率，就可以参数化从状态到动作的映射，并按回报更新其参数。这称为**策略优化**（policy optimization）。本节的更新不查询

学习到的动力学模型；价值估计器可以指导改变方向，却不负责预测环境转移。

3.3.1 策略梯度与回报梯度估计

先考虑怎样从随机轨迹求出策略参数的上升方向。我们暂用有限状态动作和固定时域 H，以便逐项对轨迹概率求导；策略 $\pi_{\theta,t}(a \mid s)$ 可依赖时间，在所讨论参数邻域内可微，并对合法动作严格为正。初始分布和环境核不依赖 θ，奖励有界。记轨迹 $\tau = (s_0, a_0, r_0, \dots, s_H)$，用其折扣奖励和的期望比较候选参数，目标是增大 J_H；G_t^H 则保存动作 t 以后仍可影响的回报：

$$J_H(\theta) = \mathbb{E}_{\tau \sim p_\theta}\left[\sum_{t=0}^{H-1} \gamma^t r_t\right], \qquad G_t^H = \sum_{k=t}^{H-1} \gamma^{k-t} r_k. \tag{3.25}$$

策略的随机性提供了一个可求导的概率模型。无需知道某次动作怎样改变后继状态的导数，也能利用“这次轨迹的概率如何随参数变化”来估计回报梯度。

定理 3.11　有限时域似然比策略梯度　在上述条件下，令 $\boldsymbol{z}_t = \nabla_\theta \log \pi_{\theta,t}(a_t \mid s_t)$，则

$$\nabla_\theta J_H = \mathbb{E}\left[\sum_{t=0}^{H-1} \gamma^t \boldsymbol{z}_t G_t^H\right]. \tag{3.26}$$

证明　轨迹分布分解为

$$p_\theta(\tau) = \rho_0(s_0) \prod_{t=0}^{H-1} \pi_{\theta,t}(a_t \mid s_t) p(s_{t+1}, r_t \mid s_t, a_t).$$

环境项的导数为 0，因此 $\nabla p_\theta = p_\theta \sum_t \boldsymbol{z}_t$。有限状态动作和有限时域下，可以对策略概率的有限和逐项求导；随机奖励的有界性保证相应积分可交换。于是

$$\nabla J_H = \mathbb{E}\left[\sum_{t=0}^{H-1} \boldsymbol{z}_t \sum_{k=0}^{H-1} \gamma^k r_k\right].$$

令 h_t 为抽取 a_t 前的全部历史，则

$$\mathbb{E}[\boldsymbol{z}_t \mid h_t] = \sum_a \pi_{\theta,t}(a \mid s_t) \nabla \log \pi_{\theta,t}(a \mid s_t) = \nabla \sum_a \pi_{\theta,t}(a \mid s_t) = \mathbf{0}.$$

当 $k < t$ 时，r_k 已经包含在 h_t 中，故 $\mathbb{E}[\boldsymbol{z}_t r_k] = \mathbf{0}$。删去这些过去奖励，余下 $\sum_{k=t}^{H-1} \gamma^k r_k = \gamma^t G_t^H$，即得结论。 ■

更新路径	所需可计算信息	不要求什么，以及主要代价
REINFORCE	策略概率或密度及其对数梯度，采样回报	不求环境导数；长回合的梯度方差可能很大
确定性策略梯度	策略对参数的导数，$Q(s,a)$ 对动作的导数	不枚举连续动作；依赖评论家的动作方向导数
参数黑盒搜索	给定一组策略参数后可评估回报	不要求策略或环境可微；需支付多组参数的整轨迹评估成本

表 3.14 直接优化策略时的三类信息需求。表中“无需模型导数”不等于“无需真实交互”。

过去奖励的删除依据是得分函数对抽样前历史的条件均值为 0；未来奖励前的时间权重并未消失。每个动作仍按 γ^t 计入起点目标。以 N 条独立同策略回合的 $N^{-1}\sum_{i,t}\gamma^t \boldsymbol{z}_{i,t} G_{i,t}^{H}$ 作更新方向，就是一种 REINFORCE 估计。完整回报包含环境噪声与之后所有动作的随机性，因而无偏不等于低方差；但它不要求对环境转移求导[44]。

[44] R. J. Williams, *Simple Statistical Gradient-Following Algorithms for Connectionist Reinforcement Learning* In Machine Learning, 1992, vol. 8, pp. 229–256

有限时域公式按时刻累加贡献。推广到无限折扣任务时，可以把这些访问概率汇总成一个状态分布，但需要先保证无限求和与求导可交换。采用平稳策略，并要求例如奖励与邻域内得分函数 $\nabla \log \pi_\theta$ 一致有界，就能对折扣级数及导数建立可积支配。再将给定状态动作的平均未来回报写成 Q^{π_θ}，得到

$$\nabla_\theta J(\theta) = \frac{1}{1-\gamma}\mathbb{E}_{\substack{s\sim d^{\pi_\theta} \\ a\sim\pi_\theta(\cdot|s)}} \left[\nabla_\theta \log \pi_\theta(a \mid s) Q^{\pi_\theta}(s,a)\right]. \tag{3.27}$$

这里 d^π 始终是归一化折扣占用分布，J 始终是未归一化回报。若从固定长度回合中均匀抽时间步，却省去 γ^t，所得权重通常不是 d^π；调节学习率可以吸收整体常数，却不能修正不同时间步的相对权重。平均奖励目标、几何随机终止采样或特定工程近似各有自己的口径，不应把它们都称为式(3.27)的精确实现[45]。

[45] R. S. Sutton, D. McAllester, S. Singh, Y. Mansour, *Policy Gradient Methods for Reinforcement Learning with Function Approximation* In Advances in Neural Information Processing Systems, 2000, pp. 1057–1063

表3.14比较了三种改变策略的路径。确定性策略梯度将在后文展开；此处重要的是，参数可调并不意味着必须使用似然比，也不意味着能够穿过环境反向传播。

3.3.2 基线、优势与方差控制

在本来就容易获得高回报的状态，许多动作都可能得到较大的 G_t。直接以 G_t 加权，某次抽中的动作会因此获得很大更新，即使它没有优于其他动作；这些偶然更新可以在平均后相消，却增加了有限样本波动。**基线**（baseline）为回报设一个比较水平。若这个水平在本轮选动作之前已确定，减去它不会改变平均梯度，并可能去掉与本轮动作优劣无关的波动。

定理 3.12　动作抽样前基线的零均值性质　设 b_t 在抽取 a_t 前已由历史 h_t 确定，且相关乘积可积。则

$$\mathbb{E}[\nabla_\theta \log \pi_{\theta,t}(a_t \mid s_t) b_t] = \mathbf{0}.$$

因而在式(3.26)中以 $G_t^H - b_t$ 替换 G_t^H，不改变期望梯度。

证明　条件于 h_t，基线是常数，故

$$\mathbb{E}[\boldsymbol{z}_t b_t \mid h_t] = b_t \sum_a \pi_{\theta,t}(a \mid s_t) \nabla \log \pi_{\theta,t}(a \mid s_t) = b_t \nabla 1 = \mathbf{0}.$$

再对历史取期望，逐时刻相加即可。基线是否准确没有进入等式；进入等式的是它对本轮动作抽样的条件独立性。 ■

因此，用一个粗糙但预先固定的 $V_{\boldsymbol{w}}(s_t)$ 减去完整回报，不会仅因价值误差而引入偏差。这里将基线作为停止求导的控制变量；若把 $-\log \pi_\theta(a_t \mid s_t)(G_t - b_\theta(s_t))$ 当成普通损失并让梯度穿过 b_θ，就多出不属于上述估计的项。同批动作被用于拟合基线后再评价这些动作时，拟合参数也可能携带该动作的信息，需用独立批次、交叉拟合或相应分析恢复所需条件。

零均值性质允许许多基线，并没有指出哪一个最能减小方差。固定状态后，各动作的得分向量长度也会影响梯度波动，所以最小方差基线不总是 $V^\pi(s)$。假定相关二阶矩有限且 $\mathbb{E}[\|\boldsymbol{z}\|^2 \mid s] > 0$；由于基线不改变梯度均值，最小化其方差等价于在实数 b 上最小化向量估计的二阶矩 $\mathbb{E}[\|\boldsymbol{z}\|^2 (G - b)^2 \mid s]$，对 b 求导可得

$$b_*(s) = \frac{\mathbb{E}[\|\boldsymbol{z}\|^2 G \mid s]}{\mathbb{E}[\|\boldsymbol{z}\|^2 \mid s]}.$$

若分母为 0，则给定该状态时 $\boldsymbol{z}$ 几乎处处为零，任意有限基线对梯度的贡献都相同，无须使用这个比值。分母为正时，只有得分长度对回报的加权不改变条件均值等额外条件成立，$b_*(s)$ 才等于 $V^\pi(s)$。实践仍常用价值基线，是因为它可学习、易复用，并直接给出优势 $A^\pi = Q^\pi - V^\pi$ 的解释。

上述基线论证仍使用完整回报。如果需要在远处奖励出现前更新，就必须让价值预测替代未观察的未来，这会增加自举依赖。我们先把多步回报减去当前状态基线，得到多步优势估计；它评价本次动作比状态的一般水平多带来多少回报。给定长度 L 的片段，暂时冻结 $V_{\boldsymbol{w}}$，令

$$\delta_{t+l} = r_{t+l} + \gamma V_{\boldsymbol{w}}(s_{t+l+1}) - V_{\boldsymbol{w}}(s_{t+l}), \qquad \widehat{A}_t^{[n]} = \sum_{l=0}^{n-1} \gamma^l \delta_{t+l}.$$

相邻价值项抵消，故 $\widehat{A}_t^{[n]} = G_t^{[n]} - V_{\boldsymbol{w}}(s_t)$，方括号仍表示回报长度。**广义优势估计**（generalized advantage estimation, GAE）把不同长度的优势作几何混合：

$$\begin{aligned}\widehat{A}_t^{\mathrm{GAE}} &= (1-\lambda)\sum_{n=1}^{L-1}\lambda^{n-1}\widehat{A}_t^{[n]} + \lambda^{L-1}\widehat{A}_t^{[L]} \\ &= \sum_{l=0}^{L-1}(\gamma\lambda)^l\delta_{t+l}, \qquad 0 \le \lambda \le 1. \end{aligned} \tag{3.28}$$

第二个等式来自对每个 δ_{t+l} 汇总其在所有 $n > l$ 中的权重，系数恰为 $\gamma^l\lambda^l$。最后一项的特殊权重保留了有限片段末端的全部剩余质量，不能直接丢掉。

图3.10给出三个 TD 误差的教学计算。取 $\gamma = 0.9$、$\lambda = 0.8$，误差与加权结果为

$$(\delta_t, \delta_{t+1}, \delta_{t+2}) = (0.2, -0.1, 0.5), \qquad \widehat{A}_t = 0.3872.$$

其中 $0.3872 = 0.2 - 0.72(0.1) + 0.5184(0.5)$。从后往前递推 $\widehat{A}_j = \delta_j + \gamma\lambda\widehat{A}_{j+1}$ 即可线性时间计算整段优势。记片段结束时刻为 $T = t + L$，先令优势累积器 $\widehat{A}_T = 0$，再从 $j = T-1$ 递推到 t。非终止的批次边界仍保留 $V_{\boldsymbol{w}}(s_T)$，但它只进入最后一个 TD 误差 δ_{T-1}，不能再用来初始化 $\widehat{A}_T$；真正终止时则令该末端状态价值为 0。片段不跨越回合重置，不能把下一回合的优势传回上一回合。

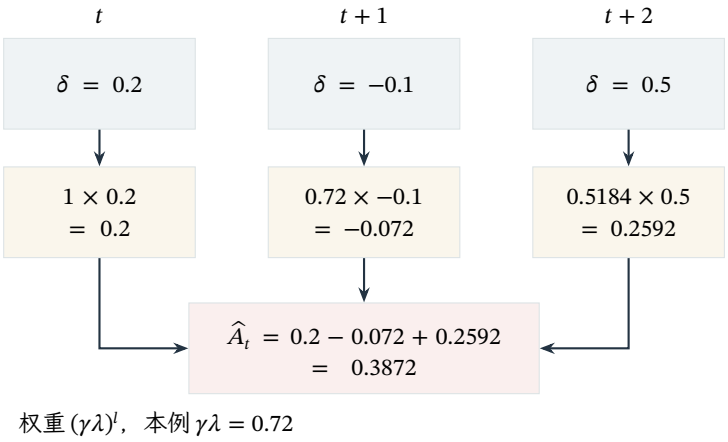


图 3.10　GAE 的几何加权。每列是一项 TD 误差及其对当前优势的贡献；数值是人工指定的三步算例，不是实验学习曲线。

若评论家等于 V^π，后继 TD 误差在其动作抽样前历史下均值为 0；因此在同策略条件下，对任意 λ，上式给定 (s_t, a_t) 的条件均值均为 $A^\pi(s_t, a_t)$。

评论家的位置	估计示例	偏差和方差应怎样判断
状态基线	完整 $G_t - V_{\boldsymbol{w}}(s_t)$	动作抽样前固定即可保持期望；误差影响方差，不保证一定降方差
未来回报替代	$r_t + \gamma V_{\boldsymbol{w}}(s_{t+1}) - V_{\boldsymbol{w}}(s_t)$	后继误差可随动作变化，通常产生自举偏差
多步混合	式(3.28)	λ 和片段长度共同控制自举依赖与随机回报范围
同批拟合再复用	用该动作的回报训练基线并立即扣减	必须重新检查条件独立、旧策略比率与重复优化造成的分布变化

表 3.15 减去一个数，与用一个数替代尚未观察的未来，是不同操作。

近似评论家则不同。令 $e = V_{\boldsymbol{w}} - V^{\pi}$，在无限折扣和有界误差下，近似 GAE 相对精确 GAE 的条件均值变化为

$$-e(s_t) + \gamma(1-\lambda)\,\mathbb{E}\left[\sum_{l=1}^{\infty}(\gamma\lambda)^{l-1}e(s_{t+l})\,\middle|\,s_t, a_t\right].$$

第一项仍是状态基线，乘得分函数后均值为 0；第二项通常依赖所选动作，会改变策略更新。$\lambda = 1$ 且完整终止回报可用时，这个自举误差项消失；若仅有截断片段，还留有末端价值误差。表3.15将两种评论家用途并排，避免把控制变量的无偏结论错误搬到所有自举目标上[46]。

[46] J. Schulman, P. Moritz, S. Levine, M. Jordan, P. Abbeel, *High-Dimensional Continuous Control Using Generalized Advantage Estimation* In International Conference on Learning Representations, 2016

3.3.3 自然梯度、信赖域与近端更新

梯度给出方向，步长还需反映动作分布会改变多少。参数距离本身不能提供统一尺度：二动作策略写成 $p = \sigma(\theta)$ 时，θ 从 0 增至 0.1，p 约增至 0.5250；同一策略族改用 $\phi = 10\theta$，让 ϕ 增加 0.1，p 却只增至约 0.5025。相同坐标步长产生了不同的行为变化，因此需要直接用新旧动作分布的差异衡量更新。

令旧参数为 θ、候选新参数为 $\theta + \boldsymbol{\Delta}$。我们用 KL 散度比较每个状态的新旧动作分布，并按旧策略占用分布平均，使本次局部比较的状态权重固定。在常规可微和支撑条件下，其二阶展开为

$$\mathbb{E}_{d^{\pi}}\left[\mathrm{KL}(\pi_{\theta}(\cdot \mid s)\|\pi_{\theta+\boldsymbol{\Delta}}(\cdot \mid s))\right] = \frac{1}{2}\boldsymbol{\Delta}^{\top}\boldsymbol{F}\boldsymbol{\Delta} + o(\|\boldsymbol{\Delta}\|^2),$$
$$\boldsymbol{F} = \mathbb{E}_{d^{\pi},\pi}[\boldsymbol{z}\boldsymbol{z}^{\top}]. \tag{3.29}$$

一次项因概率归一化而消失；二次项 $\boldsymbol{F}$ 是 Fisher 信息矩阵，衡量参数变化在动作分布中留下多大痕迹。**自然梯度**用这个局部度量而不是坐标长度比较方向。设 $\boldsymbol{g} = \nabla J$ 在有效子空间内非零、$\boldsymbol{F}$ 在该子空间正定且 $\delta > 0$，则

$$\underset{\boldsymbol{\Delta}:\,\boldsymbol{\Delta}^{\top}\boldsymbol{F}\boldsymbol{\Delta}/2 \le \delta}{\arg\max}\ \boldsymbol{g}^{\top}\boldsymbol{\Delta} = \sqrt{\frac{2\delta}{\boldsymbol{g}^{\top}\boldsymbol{F}^{-1}\boldsymbol{g}}}\,\boldsymbol{F}^{-1}\boldsymbol{g}.$$

若 $\boldsymbol{g}=\mathbf{0}$，局部线性目标没有偏好的上升方向，可取零步；上述归一化公式不适用。若参数冗余导致 $\boldsymbol{F}$ 奇异，应限制到可辨识子空间、使用伪逆，或明确采用 $\boldsymbol{F}+\xi \boldsymbol{I}$ 的阻尼近似。自然梯度的坐标不变性是局部几何性质，不是任意有限步长的回报保证[47]。

局部分布距离说明如何计量一步，却还没有保证回报会上升。要判断改进，需将新策略的回报差写成可评价的优势。下面的恒等式表明：应平均的是新策略实际访问状态上的旧策略优势，不能任意用旧数据分布替换。

定理 3.13　折扣性能差恒等式　对有限折扣 MDP 中的两个平稳策略 π,π'，若奖励有界且初始分布同为 ρ_0，则

$$J(\pi')-J(\pi)=\frac{1}{1-\gamma}\mathbb{E}_{s\sim d^{\pi'},\,a\sim\pi'}\left[A^{\pi}(s,a)\right]. \tag{3.30}$$

证明　沿 π' 的轨迹，条件期望给出 $A^{\pi}(s_t,a_t)=\mathbb{E}[r_t+\gamma V^{\pi}(s_{t+1})-V^{\pi}(s_t)\mid s_t,a_t]$。乘 γ^t 并求和到 $n-1$，

$$\mathbb{E}_{\pi'}\sum_{t=0}^{n-1}\gamma^t A^{\pi}(s_t,a_t)=\mathbb{E}_{\pi'}\sum_{t=0}^{n-1}\gamma^t r_t-\mathbb{E}_{\rho_0}V^{\pi}(s_0)+\gamma^n\mathbb{E}_{\pi'}V^{\pi}(s_n).$$

V^{π} 有界使尾项趋于 0，前两项趋于 $J(\pi')-J(\pi)$。按归一化占用分布的定义，左边极限等于 $(1-\gamma)^{-1}\mathbb{E}_{d^{\pi'},\pi'}A^{\pi}$。 ■

更新前尚未收集新策略轨迹，直接计算 $d^{\pi'}$ 下的优势仍有困难。用 d^{π} 替代它，就得到一个可由旧数据估计的局部代理目标；代理提高到什么程度能支持真实改进，还要控制这项替代误差。若连动作也用旧策略样本估计，还需 $\pi'(\cdot\mid s)\ll\pi(\cdot\mid s)$，即新策略所选动作在旧策略下有正概率。此时动作比率给出

$$\mathcal{L}_{\pi}(\pi')=J(\pi)+\frac{1}{1-\gamma}\mathbb{E}_{d^{\pi},\,a\sim\pi}\left[\frac{\pi'(a\mid s)}{\pi(a\mid s)}A^{\pi}(s,a)\right].$$

动作比率校正了同一状态的动作分布，却没有校正状态访问分布。令 $\eta=\max_s \mathrm{TV}(\pi'(\cdot\mid s),\pi(\cdot\mid s))$、$\epsilon_A=\max_{s,a}|A^{\pi}(s,a)|$。由占用流方程可得 $\|d^{\pi'}-d^{\pi}\|_1\le 2\gamma\eta/(1-\gamma)$；又因 $\mathbb{E}_{\pi}A^{\pi}=0$，$|\mathbb{E}_{\pi'}A^{\pi}(s,\cdot)|\le 2\epsilon_A\eta$。两式相乘得到

$$J(\pi')\ge\mathcal{L}_{\pi}(\pi')-\frac{4\gamma\epsilon_A}{(1-\gamma)^2}\eta^2. \tag{3.31}$$

这里 η 取全部状态上动作分布总变差的最大值，因为少见状态的策略变化也可能改变后续可达区域；仅按旧访问分布平均，可能漏掉这种变化。由 Pinsker 不等式，可进一步用最大状态 KL 控制 η^2。因此，下界要求的不只

[47] S. M. Kakade, *A Natural Policy Gradient* In Advances in Neural Information Processing Systems, 2002, pp. 1531–1538

是提高旧数据上的代理，还要限制所有状态的新旧策略差异，使状态分布替代的损失不足以抵消提升。

TRPO 的理论分析从此类下界出发，实践实现则用样本平均 KL 约束、共轭梯度近似 Fisher 逆乘积和回溯线搜索，以有限计算求一个局部步。平均 KL 不控制所有少见状态，估计优势也不等于真实优势，因此“精确下界提高”与“实践 TRPO 更新”不能无条件互换。兼容函数逼近给出了另一条严格但受限的连接：若评论家为 $f_{\boldsymbol{w}}(s,a)=\boldsymbol{z}(s,a)^{\top}\boldsymbol{w}$，并在同一 $d^{\pi}\pi$ 下精确最小化 $\mathbb{E}[(Q^{\pi}-b(s)-f_{\boldsymbol{w}})^2]$，正规方程给出 $\mathbb{E}[\boldsymbol{z}(Q^{\pi}-b-f_{\boldsymbol{w}})]=0$，从而 $\nabla J=\boldsymbol{F}\boldsymbol{w}/(1-\gamma)$。这要求特征兼容、正确加权和评价解足够准确，不是任意价值网络都保留梯度方向[48]。

[48] J. Schulman, S. Levine, P. Moritz, M. Jordan, P. Abbeel, *Trust Region Policy Optimization* In Proceedings of the 32nd International Conference on Machine Learning, 2015, pp. 1889–1897

TRPO 的约束求解需要额外计算。PPO 改为优化一个可用于小批量更新的代理，限制过度改变动作概率后还能从同一样本获取多少收益。记旧策略为 π_{old}，$q_t(\theta)=\pi_\theta(a_t\mid s_t)/\pi_{\text{old}}(a_t\mid s_t)$，优势在本轮优化中固定。PPO-Clip 最大化

$$L^{\text{clip}}(\theta)=\widehat{\mathbb{E}}_t\left[\min\left\{q_t\widehat{A}_t,\ \text{clip}(q_t,1-\varepsilon,1+\varepsilon)\widehat{A}_t\right\}\right]. \tag{3.32}$$

这里 $\widehat{\mathbb{E}}_t$ 使用明确选定的批次权重；若要对应前述折扣代理，权重应匹配 $d^{\pi_{\text{old}}}$，均匀抽时间步未必满足。内部最小值是在未裁剪和裁剪后的两项贡献中取较小者，使过大的有利概率变化不再增加代理收益：$\widehat{A}_t>0$ 时，$q_t>1+\varepsilon$ 进入平坦区；$\widehat{A}_t<0$ 时，$q_t<1-\varepsilon$ 进入平坦区。反方向变化仍受惩罚。外层则对策略参数最大化这个批次目标。图3.11展示两种优势符号下的曲线，并与参数化例子对照。

例如正优势为 1、概率比从 1.2 变到 1.5，单样本贡献仍为 1.2；但共享参数受其他样本影响，仍可能继续推动这个比率。PPO-KL 改用 $\widehat{\mathbb{E}}[q_t\widehat{A}_t]-\beta\widehat{\mathbb{E}}_s\,\text{KL}(\pi_{\text{old}}\|\pi_\theta)$ 并调节惩罚系数，两者都需要监控实际策略变化。算法3.2给出一次完整数据循环；工程上常加熵项、优势标准化、梯度裁剪与 KL 提前停止，应分别记录，不能混作裁剪目标的数学性质[49]。

[49] J. Schulman, F. Wolski, P. Dhariwal, A. Radford, O. Klimov, *Proximal Policy Optimization Algorithms*, 2017, arXiv: 1707.06347

算法 3.2 一轮 PPO-Clip：采样、固定目标与近端优化

1: 保存 $\theta_{\text{old}}\leftarrow\theta$，冻结旧策略与本轮用于估计优势的评论家。
2: 用 π_{old} 收集片段，记录状态、动作、r_t、真实终止标记、截断标记和旧对数概率。
3: 真实终止处置末端价值为 0；非终止片段边界使用冻结评论家的末端预测。
4: 从后向前计算式(3.28)，固定 $\widehat{A}_t$ 与价值目标 $\widehat{R}_t=\widehat{A}_t+V_{\text{old}}(s_t)$。
5: **for** 预先指定的 E 轮小批量优化 **do**
6: 　从本轮数据取批次，按已声明权重计算 q_t 与 L^{clip}。
7: 　行动者对 L^{clip} 做梯度上升；评论家对 $(V_{\boldsymbol{w}}(s_t)-\widehat{R}_t)^2$ 做下降。

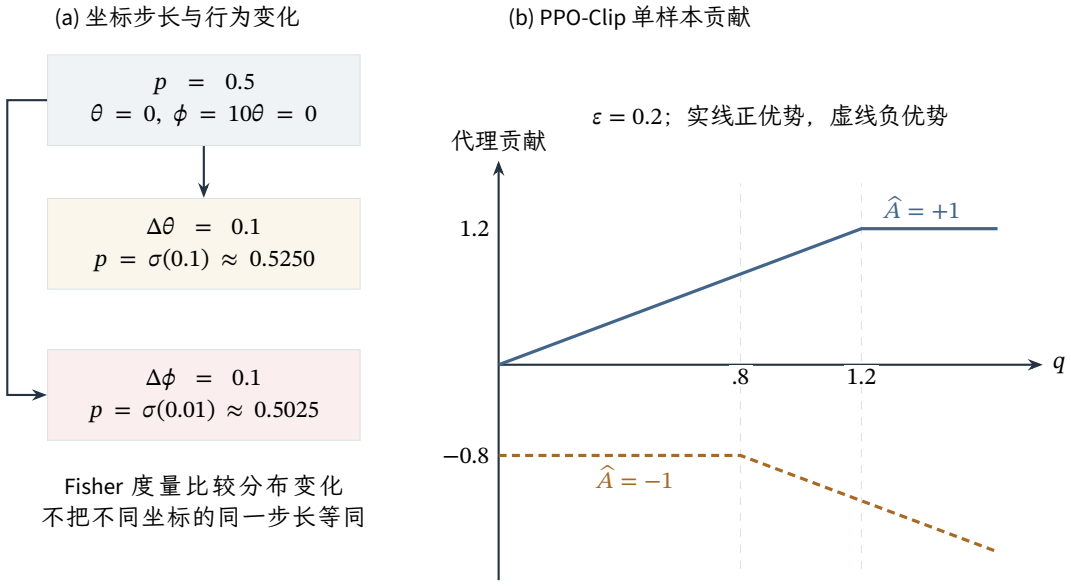


图 3.11 参数距离、分布距离与 PPO 裁剪。左侧为同一 Bernoulli 策略的两种坐标；右侧为 $\varepsilon = 0.2$、$\widehat{A} = \pm 1$ 时式(3.32)的解析折线，裁剪后的平坦区不表示概率比被硬性截住。

8: 测量旧新策略 KL；若采用提前停止规则且超过阈值，停止本轮行动者更新。
9: **end for**
10: 丢弃本轮作为近端优化依据的旧数据，使用新策略开始下一轮真实采样。

多轮优化复用的是同一个旧分布上的代理，不是每轮都重新获得同策略无偏梯度。理论单调改进是关于特定精确下界和约束的结论；局部平稳性是优化算法的另一类结论；表格 softmax 等特殊参数化下的全局分析又要求另外的条件。一般神经网络 PPO 不能从名称中的“近端”继承这三种保证。

3.3.4 行动者—评论家的评价—改进耦合

前面已用价值基线和优势帮助计算策略更新；实际训练还需要随策略变化不断重学这些评价量。**行动者—评论家**（actor–critic）将两个过程耦合：行动者是产生动作的参数策略，评论家是为其更新估计价值或优势的函数。最终目标仍是改进策略，而不是分别追求两个不相关的数值。行动者改变后，评论家的目标策略及后续样本分布也改变，因此必须检查两个更新能否相互跟踪。

接口	数据与更新时机	需要检查的条件
一步 AC	一次转移后更新价值与策略	TD 自举误差、步长、样本权重
A2C	多环境短片段同步形成一个更新批次	批次内策略版本和终止处理一致；并行仅改变采样组织
A3C	工作进程使用局部参数采样，异步提交梯度	参数滞后与更新冲突；当前全局参数下通常已非严格同策略
带 GAE 的 AC	冻结评价器构造片段优势，再更新策略	λ、末端自举与估计器是否固定；重复批次优化另需分布处理

表 3.16 行动者—评论家的数据接口。同步、异步与优势长度是可以组合的不同维度。

对同策略的一步经验，先用奖励和后继估值构造 TD 误差；评论家据此修正当前价值，行动者则把这个误差当作本次动作的优势。为了与折扣起点目标一致，行动者贡献仍保留 γ^t。一种最简单的联合更新为

$$\begin{aligned}\delta_t &= r_t + \gamma(1 - z_t)V_{\boldsymbol{w}}(s_{t+1}) - V_{\boldsymbol{w}}(s_t),\\ \boldsymbol{w} &\leftarrow \boldsymbol{w} + \beta_t \delta_t \nabla_{\boldsymbol{w}} V_{\boldsymbol{w}}(s_t),\\ \theta &\leftarrow \theta + \alpha_t \gamma^t \delta_t \nabla_\theta \log \pi_\theta(a_t \mid s_t).\end{aligned} \tag{3.33}$$

z_t 仅表示真实终止；若按 d^π 直接抽样状态动作，则可把最后一行改写成含 $1/(1-\gamma)$ 的占用分布梯度口径。这里保留回合时间权重，是为了与本章的 J 一致。评论家采用半梯度，行动者把 δ_t 当成停止求导的优势估计，两个梯度不能混在一起。多步行动者—评论家用 n 步优势或 GAE 替换 δ_t；资格迹则把更新沿过去状态动作传播。

示例 3.14 同一经验的两种更新 在基准网格起点 $(1,1)$，两个合法意图动作是向右和向上。假设当前评论家估计 $V(1,1)=0.2$、$V(2,1)=0.5$，策略以 $p_{右}=\sigma(\theta)$、$\theta=0$ 表示，均为本次手算指定的初值。第一步选右且实际到达 $(2,1)$，得到 $r_0=-0.04$，于是 $\delta_0=-0.04+0.9(0.5)-0.2=0.21$。取评论家步长 0.1，表格状态值更新为 0.221；取行动者步长 0.2，因 $\partial_\theta \log p_{右}=1-p_{右}=0.5$，$\theta$ 更新为 0.021，向右概率变为约 0.50525。前者提高当前状态的估值，后者提高相对于当前基线表现较好的动作概率；两者不在拟合同一个数。

图3.12中的两条反馈路径解释了耦合来源。评论家输出会改变行动者的训练目标，行动者又会改变评论家以后看见的样本。即使一次评论家回归收敛，也不代表整个反馈过程已经稳定。

A2C 常把多个采样器在同一组参数下收集的短片段同步汇总再更新；A3C 则允许采样器异步贡献梯度[50]。表3.16把这一区别落实到目标的数据条件。异步减少等待，不会让旧参数产生的动作自动变成当前策略动作。

[50] V. Mnih, A. P. Badia, M. Mirza, A. Graves, T. Lillicrap, T. Harley, D. Silver, K. Kavukcuoglu, *Asynchronous Methods for Deep Reinforcement Learning* In Proceedings of the 33rd International Conference on Machine Learning, 2016, pp. 1928–1937

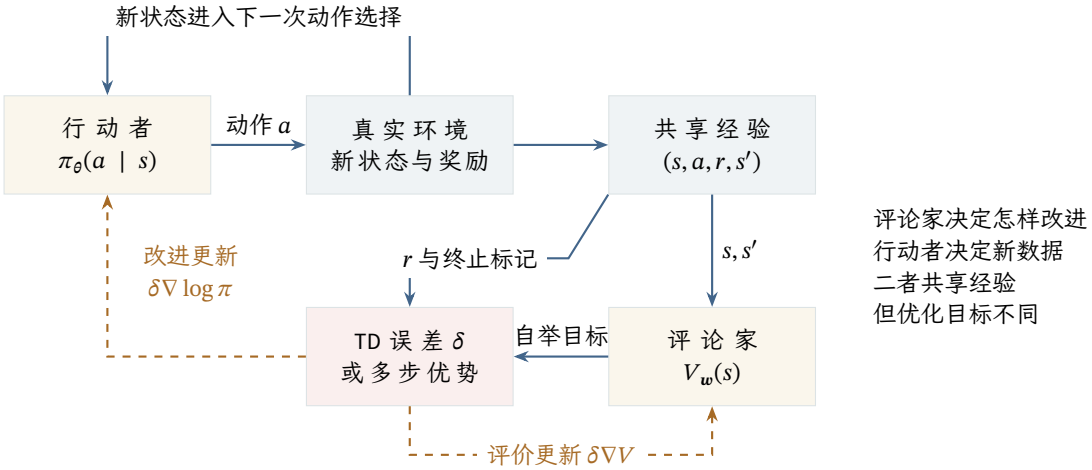


图 3.12 行动者—评论家的共享经验与两条反馈路径。蓝色实线表示采样和估计，橙色虚线表示参数更新的依据；图中的评论家不是环境模型。

经典双时间尺度分析让评论家比行动者变化得快。若评论家步长为 β_t、行动者为 α_t，典型要求为两者的和发散、平方和收敛，并有 $\alpha_t/\beta_t \to 0$。再加上适用的遍历性、平滑性、参数有界性以及评论家在固定策略下存在稳定且可跟踪的解，快速过程可近似看成已经评价了当前策略，慢速过程才接近一个策略改进常微分方程。线性或兼容评论家等参数化条件决定这个方程是否为真正梯度场；非凸参数化的结果通常也只是局部或驻点性质。固定大步长、任意共享深度网络及不受控参数滞后均不由这条证明路线覆盖[51]。

[51] V. R. Konda, J. N. Tsitsiklis, *Actor-Critic Algorithms* In Advances in Neural Information Processing Systems, 2000, pp. 1008–1014

3.3.5 连续动作、离策略与最大熵更新

连续动作无法逐个比较，但若评论家能给出动作附近的价值变化，就可以沿价值上升方向调整行动者输出。令确定性行动者为 $a = f_\theta(s)$，其诱导策略为 π_θ。确定性策略梯度（deterministic policy gradient, DPG）先求 Q 对动作的导数，再通过行动者传到参数；若所需函数可微、导数可积，则

$$\nabla_\theta J = \frac{1}{1-\gamma}\mathbb{E}_{s\sim d^{\pi_\theta}}\left[(\nabla_\theta f_\theta(s))^{\top}\, \nabla_a Q^{\pi_\theta}(s,a)\big|_{a=f_\theta(s)}\right]. \tag{3.34}$$

行动者沿评论家认为价值上升的动作方向移动，再用链式法则把这个方向传到参数。环境仍不必可微，但评论家的动作导数必须有意义；动作上的函数值误差小，也不保证动作导数准确[52]。

DDPG 把确定性行动者、评论家、经验回放与缓慢跟踪的目标网络组合起来[53]。它用回放数据训练 $Q_{\boldsymbol{w}}$，目标为 $y = r + \gamma(1-z)Q_{\bar{\boldsymbol{w}}}(s', f_{\bar{\theta}}(s'))$，并用回放状态上的 $\nabla_\theta f^{\top}\nabla_a Q_{\boldsymbol{w}}$ 更新行动者。横线表示缓慢移动的目标参数。真实执行常在确定性输出上叠加探索噪声，再投影到动作约束内；探索用的噪声不等于行动者目标本身。

[52] D. Silver, G. Lever, N. Heess, T. Degris, D. Wierstra, M. Riedmiller, *Deterministic Policy Gradient Algorithms* In Proceedings of the 31st International Conference on Machine Learning, 2014, pp. 387–395

[53] T. P. Lillicrap, J. J. Hunt, A. Pritzel, N. Heess, T. Erez, Y. Tassa, D. Silver, D. Wierstra, *Continuous Control with Deep Reinforcement Learning* In International Conference on Learning Representations, 2016

记固定回放状态分布为 ν。它可能混合多个历史行为策略，并不一定是某一策略的归一化折扣占用，通常也不同于式(3.34)中的 d^{π_θ}。若另以该分布为起点定义目标

$$J_\nu(\theta) = \mathbb{E}_{s\sim\nu} V^{\pi_\theta}(s),$$

其精确梯度的状态权重仍是从 ν 出发、沿当前策略继续访问形成的折扣占用，而不只是 ν 本身。仅用回放状态的链式乘积，是一个固定状态权重的行动者代理或相应离策略近似；忽略未来访问对参数的依赖，不能被“数据可以复用”替代为精确性证明。

TD3 在这个接口上处理三类不同误差。双评论家的较小值降低目标过估计，目标动作平滑限制行动者利用极窄的价值尖峰，延迟行动者更新则让评论家先消化若干批次数据。其目标可写成

$$\tilde{a}' = \mathrm{proj}_{\mathcal{A}}\big(f_{\bar\theta}(s') + \mathrm{clip}(\epsilon, -c, c)\big), \qquad y = r + \gamma(1-z)\min_{j=1,2} Q_{\bar{\boldsymbol{w}}_j}(s', \tilde{a}').$$

ϵ 是人为加入的目标噪声，通常取零均值高斯。TD3 的三个部件分别调整目标估值、行动者更新时机和目标动作的局部平均[54]。较小值也可能低估；平滑尺度过大可能抹掉真实的窄最优区域。这些稳定化措施不消除所有评论家误差。

[54] S. Fujimoto, H. van Hoof, D. Meger, *Addressing Function Approximation Error in Actor-Critic Methods* In Proceedings of the 35th International Conference on Machine Learning, 2018, pp. 1587–1596

确定性输出通常另加噪声取得探索数据。另一种做法把随机性本身纳入策略目标，让高回报动作附近仍保留多个选择。**最大熵强化学习**（maximum entropy reinforcement learning）在原回报之外奖励策略熵，即动作分布的分散程度；温度 $\alpha > 0$ 决定愿意为这种分散程度付出多少回报。目标为

$$J_\alpha(\pi) = \mathbb{E}_\pi \sum_{t\ge 0} \gamma^t \big[r_t - \alpha \log \pi(a_t \mid s_t)\big]. \tag{3.35}$$

这已经改变优化目标，不只是降低原目标梯度的方差。有限动作下，熵是 $H(p) = -\sum_a p_a \log p_a$；连续动作下使用给定参考测度的密度和微分熵，其数值依赖动作尺度，甚至可以为负。

要从这个目标得到一次策略改进，可以先固定某状态的动作评分 q_a，只优化该处的动作概率。候选集合是有限合法动作上的全部概率分布 $\Delta(\mathcal{A})$；我们最大化平均评分加熵，而非硬选一个最大动作。下面的恒等式给出这一局部问题的确切解。

定理 3.15　熵正则的变分恒等式　对有限动作集上的任意实数 q_a 及 $\alpha > 0$，

$$\max_{p\in\Delta(\mathcal{A})} \left\{ \sum_a p_a q_a + \alpha H(p) \right\} = \alpha \log \sum_a e^{q_a/\alpha}.$$

唯一最优分布为 $p^*_a = e^{q_a/\alpha} / \sum_b e^{q_b/\alpha}$。

证明 令 $Z=\sum_a e^{q_a/\alpha}$，则 $\log p_a^*=q_a/\alpha-\log Z$。对任意 p，

$$\sum_a p_a q_a+\alpha H(p)=\alpha\log Z-\alpha\sum_a p_a\log\frac{p_a}{p_a^*}=\alpha\log Z-\alpha\,\mathrm{KL}(p\|p^*).$$

KL 非负且仅在 $p=p^*$ 时为 0，得到最大值与唯一性。所有 q_a 有限保证 $p_a^*>0$，因此没有未定义的支撑比率。 ■

固定策略的软价值采用一致的熵位置约定：

$$\begin{aligned}Q_\alpha^\pi(s,a)&=R(s,a)+\gamma\mathbb{E}[V_\alpha^\pi(s')\mid s,a],\\ V_\alpha^\pi(s)&=\mathbb{E}_{a\sim\pi}[Q_\alpha^\pi(s,a)-\alpha\log\pi(a\mid s)].\end{aligned}\tag{3.36}$$

这里 Q_α^π 不含当前动作的熵，V_α^π 含当前策略熵。上面的变分恒等式据此给出软策略改进。连续动作可把求和换为积分，但须满足分区函数有限及相关熵、回报可积；在无界动作空间上，常数 q 的指数函数就不能归一化成密度。

连续动作的 Boltzmann 分布往往难以直接归一化和抽样，SAC 改用可训练的参数策略近似软改进。可重参数化指先抽与参数无关的噪声，再通过可微变换生成动作，从而能够沿动作传导评论家梯度。以有界动作为例，$\boldsymbol{u}=\boldsymbol{m}_\theta(s)+\boldsymbol{\sigma}_\theta(s)\odot\epsilon$、$\epsilon\sim\mathcal{N}(\mathbf{0},\boldsymbol{I})$、$a=\tanh\boldsymbol{u}$。动作归一化到 $(-1,1)$ 时，密度必须包含变换 Jacobian：

$$\log\pi_\theta(a\mid s)=\log\mathcal{N}(\boldsymbol{u};\boldsymbol{m}_\theta,\operatorname{diag}\boldsymbol{\sigma}_\theta^2)-\sum_i\log(1-\tanh^2 u_i).$$

若再缩放到物理动作区间，还需加入该线性变换的对数行列式。漏掉 Jacobian 会同时改变熵、行动者梯度和温度更新。

动作密度确定后，评论家和行动者还需使用不同样本：评论家评价回放中实际记录的动作，行动者则在回放状态上重新生成当前策略动作，以提高软价值。采用不单设价值网络的常见 SAC 版本，在后继状态采样 $a'\sim\pi_\theta(\cdot\mid s')$，并记当前状态重采样动作为 $a_\theta=f_\theta(s,\epsilon)$。回放批次中一次目标和两个损失为

$$\begin{aligned}y&=r+\gamma(1-z)[\min_j Q_{\bar{\boldsymbol{w}}_j}(s',a')-\alpha\log\pi_\theta(a'\mid s')],\\ L_Q(\boldsymbol{w}_j)&=\tfrac{1}{2}\widehat{\mathbb{E}}_{\mathcal{D}}[(Q_{\boldsymbol{w}_j}(s,a)-\mathrm{sg}(y))^2],\\ L_\pi(\theta)&=\widehat{\mathbb{E}}_{s\sim\mathcal{D},\epsilon}[\alpha\log\pi_\theta(a_\theta\mid s)-\min_j Q_{\boldsymbol{w}_j}(s,a_\theta)].\end{aligned}\tag{3.37}$$

更新行动者时，评论家参数固定，但保留 Q 对动作的导数；更新评论家时，整个 y 停止求导。图3.13将这两个容易混淆的路径分开。表格软策略迭代

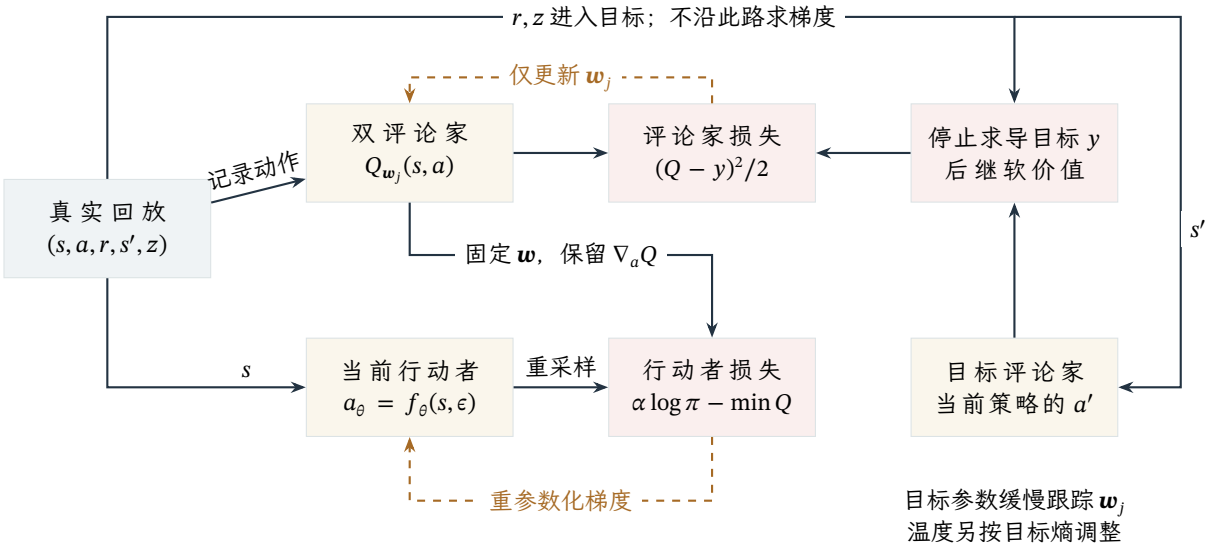


图 3.13 SAC 中不同梯度路径的职责。上排用记录动作评价评论家，下排从当前行动者重采样动作；目标中的后继动作也是当前策略采样，目标评论家采用缓慢移动的参数。

中精确评价和精确改进的结论，并不能证明这两个近似神经网络损失在任意回放分布下收敛[55]。

温度可以由目标熵 H_0 自动调整。令 $\alpha = e^{\xi}$，对 $L_\alpha(\xi) = \widehat{\mathbb{E}}[e^{\xi}(-\log \pi_\theta(a \mid s) - H_0)]$ 下降，且在此步固定策略样本和对数密度。当前熵低于目标时梯度为负，ξ 上升，从而提高探索的熵奖励；高于目标时方向相反。连续动作的 H_0 可以为负，不应把它当成离散动作数的对数。算法3.3明确了更新顺序；独立价值网络被移除与自动温度来自后续 SAC 算法版本，应与最初论文的实现区分[56]。

算法 3.3 SAC 的真实数据与离策略更新循环

初始化策略、两个评论家、对应目标评论家、温度及真实回放 $\mathcal{D}$。
for 每个真实交互步 **do**
  由当前策略采样动作并执行，记录 (s,a,r,s',z)；预热阶段可使用指定随机策略。
  将经验写入 $\mathcal{D}$；真实终止或环境时间上限要求重置时取得新起点，否则转到 s'。
  仅时间截断仍令 $z=0$，记录中的 s' 保留重置前的后继观测。
  for 预先规定的 U 次梯度更新 **do**
    从 $\mathcal{D}$ 抽批次，在后继状态按当前策略采样 a'，构造停止求导的 y。
    两个评论家分别最小化 L_Q，不向目标网络和目标动作反向传播。
    在同批状态重新采样可重参数化动作，固定评论家参数，最小化 L_π。
    若自动调温，固定策略输出并最小化 L_α。
    目标参数更新为 $\bar{\boldsymbol{w}}_j \leftarrow (1-\tau)\bar{\boldsymbol{w}}_j + \tau \boldsymbol{w}_j$。
  end for

[55] T. Haarnoja, A. Zhou, P. Abbeel, S. Levine, *Soft Actor-Critic: Off-Policy Maximum Entropy Deep Reinforcement Learning with a Stochastic Actor* In Proceedings of the 35th International Conference on Machine Learning, 2018, pp. 1861–1870

[56] T. Haarnoja, A. Zhou, K. Hartikainen, G. Tucker, S. Ha, J. Tan, V. Kumar, H. Zhu, A. Gupta, P. Abbeel, S. Levine, *Soft Actor-Critic Algorithms and Applications*, version 2, 2018, arXiv: 1812.05905, (visited on 10/04/2026)

方法	校正或约束的位置	数据接口与边界
ACER	截断重要性比率加偏差校正项，配合 Retrace 评价及策略变化约束	回放与当前采样结合；只截断而丢掉补偿项不是相同估计器
IMPALA	V-trace 校正行为策略与学习器策略差异	解耦采样和学习；截断阈值影响评价目标，见前文 V-trace
MPO	E 步构造受 KL 约束的动作改进分布，M 步在约束下拟合参数策略	常用回放状态和评论家；动作改进与状态分布覆盖是不同问题
APPO	异步采样下结合 V-trace 目标与近端概率比代理	行为、目标和学习策略可能不同；须报告具体实现的目标同步及比率定义

表 3.17 数据复用、策略滞后和更新约束的几种组合。APPO 是实现族名称，不能假定所有版本具有同一估计目标。

13: **end for**

例如一条人工经验有 $r = 0.1$、$\gamma = 0.9$、$z = 0$，后继动作的两个目标值为 $(0.7, 0.9)$，$\log \pi(a' \mid s') = -0.5$、$\alpha = 0.2$，则 $y = 0.1 + 0.9(0.7 + 0.1) = 0.82$。若一个表格评论家当前值为 0.6，步长 0.1 的一次平方损失更新得到 0.622。在当前状态另采一个动作，若 $\min Q = 0.65$、$\log \pi = -0.8$，其行动者损失样本为 $-0.16 - 0.65 = -0.81$；这个数值还不足以决定参数步长，必须通过密度和 Q 的动作导数求梯度。它不等于用记录动作做监督学习。

离策略和近端约束也可以按其他方式组合。表3.17比较四种接口，关注的是概率比在哪个位置校正数据、哪些参数被当作旧策略，而非把分布式采样本身当成学习保证。

ACER 的重要性截断补偿需要同时保留被截断部分的期望校正；否则得到的是另一个有偏梯度[57]。Retrace 提供评价目标，策略变化约束则限制更新幅度，两者不能替代概率比支持条件。

MPO 的受约束动作分布改进与参数拟合分成两步，能分别控制非参数改进和参数投影。回放状态仍来自行为分布，动作分布上的 KL 约束并不自动解决未覆盖状态的问题[58]。

IMPALA 已经在离策略评价中出现。APPO 的具体工程版本应以使用的实现文档为准[59]。训练报告需要保存版本与配置，不能只写一个缩写就省去旧策略的定义。

3.3.6 正则化与无梯度策略搜索

熵奖励鼓励保留多个动作，KL 约束则限制离开参考行为。固定某状态的动作评分后，可以把两者写成同一个局部选择问题：在合法动作的概率分布中，增大平均评分，同时惩罚相对参考分布的 KL。给定 q_a、p_a^{ref} 和 $\alpha > 0$，考虑

$$\max_{p} \left\{ \sum_a p_a q_a - \alpha \,\mathrm{KL}(p \| p^{\mathrm{ref}}) \right\}.$$

在参考分布的正支撑上，对概率归一化约束引入乘子并求导，$q_a - \alpha(\log(p_a / p_a^{\mathrm{ref}}) + 1) - \lambda = 0$，从而

$$p_a^{\mathrm{new}} = \frac{p_a^{\mathrm{ref}} e^{q_a/\alpha}}{\sum_b p_b^{\mathrm{ref}} e^{q_b/\alpha}}. \tag{3.38}$$

参考分布取均匀分布时回到熵正则；取旧策略时得到 KL 几何下的一步镜像上升。若 $p_a^{\mathrm{ref}} = 0$，任何给该动作正质量的 p 都会产生无限 KL，更新无法重新发现它。这是支持集的限制，不是温度再小就能克服的数值问题。

图3.14上半部展示这一局部更新。相似的指数权重也可从概率条件化得到，这一视角称为**控制即推断**（control as inference）：把奖励较高的轨迹赋予较大的“最优性”事件概率，再推断条件于该事件的行为。在离散有限时域模型中，设最优性变量的条件概率与 $\exp(r_t/\alpha)$ 成比例，给定动作先验和真实动力学，轨迹后验便按指数回报重加权。不过，随机环境的精确后验还可能偏好幸运转移，而策略无法控制这种运气。要对应可执行控制，需固定变分轨迹族的真实环境核，只优化策略，并说明近似推断范围。因此这个构造可以解释某些熵与 KL 目标，不能把所有策略算法都视为同一精确后验求解[60]。

以上更新需要动作评分或梯度。若策略包含不可微程序，或者只能在整回合结束后查询回报，可以改为试验多组策略参数。**交叉熵方法**（cross-entropy method, CEM）维护参数搜索分布，保留估计回报较高的一部分候选作为精英，再拟合这些候选以改变下一轮试验范围。若搜索分布为高

[57] Z. Wang, V. Bapst, N. Heess, V. Mnih, R. Munos, K. Kavukcuoglu, N. de Freitas, *Sample Efficient Actor-Critic with Experience Replay* In International Conference on Learning Representations, 2017

[58] A. Abdolmaleki, J. T. Springenberg, Y. Tassa, R. Munos, N. Heess, M. Riedmiller, *Maximum a Posteriori Policy Optimisation* In International Conference on Learning Representations, 2018

[59] Ray RLlib Contributors, *Asynchronous Proximal Policy Optimization (APPO)*, Ray Documentation, URL: https://docs.ray.io/en/latest/rllib/rllib-algorithms.html#asynchronous-proximal-policy-optimization-appo (visited on 10/04/2026)

[60] S. Levine, *Reinforcement Learning and Control as Probabilistic Inference: Tutorial and Review*, 2018, arXiv: 1805.00909

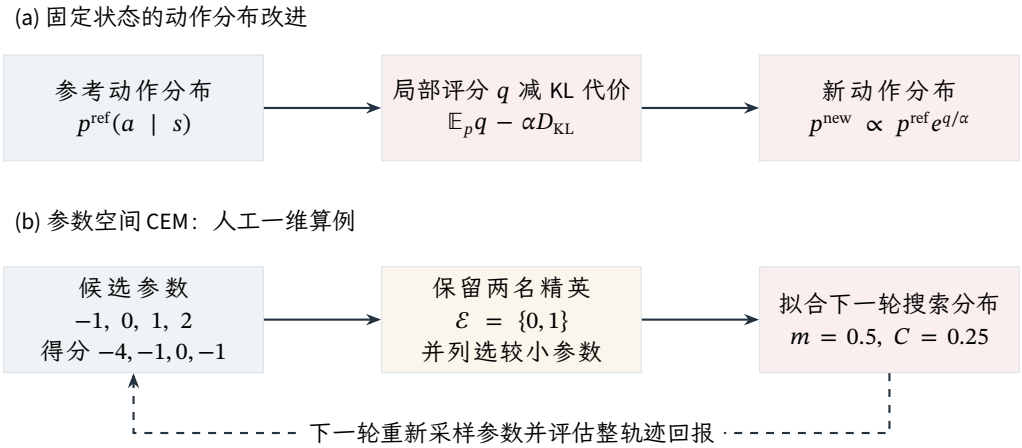


图 3.14 两类策略搜索分布。上排在固定状态对动作分布做正则化改进，下排在参数空间选择精英并拟合搜索分布；动作概率与参数采样概率不能混为一谈。

斯，第 k 轮采样 $\theta_i \sim \mathcal{N}(\boldsymbol{m}^{(k)}, \boldsymbol{C}^{(k)})$，按估计回报选出精英集合 $\mathcal{E}$，则未平滑更新为

$$\boldsymbol{m}^{(k+1)} = \frac{1}{|\mathcal{E}|} \sum_{i \in \mathcal{E}} \theta_i, \qquad \boldsymbol{C}^{(k+1)} = \frac{1}{|\mathcal{E}|} \sum_{i \in \mathcal{E}} (\theta_i - \boldsymbol{m}^{(k+1)})(\theta_i - \boldsymbol{m}^{(k+1)})^{\top}.$$

实际可设置最小协方差或平滑更新，防止过早塌缩。图3.14下半部使用独立一维教学回报 $F(\theta) = -(\theta - 1)^2$：四个候选为 $(-1, 0, 1, 2)$，得分 $(-4, -1, 0, -1)$；预先约定并列时选较小参数，保留两名精英 $(0, 1)$，得到新均值 0.5、最大似然方差 0.25。这里的候选与得分都是人工给定，不是一次真实训练的测量结果[61]。

CEM 只用精英筛选和拟合改变搜索分布，进化策略（evolution strategies, ES）还可以用参数扰动与回报的关系估计方向。先将原目标在高斯邻域内平均，定义 $F_\sigma(\theta) = \mathbb{E}_{\epsilon \sim \mathcal{N}(\mathbf{0}, \boldsymbol{I})} J(\theta + \sigma\epsilon)$，则在可积条件下

$$\nabla F_\sigma(\theta) = \frac{1}{\sigma} \mathbb{E}[J(\theta + \sigma\epsilon)\epsilon].$$

使用成对扰动可估计为 $(2N\sigma)^{-1} \sum_i [\widehat{J}(\theta + \sigma\epsilon_i) - \widehat{J}(\theta - \sigma\epsilon_i)]\epsilon_i$。

[61] R. Y. Rubinstein, *The Cross-Entropy Method for Combinatorial and Continuous Optimization* In Methodology and Computing in Applied Probability, 1999, vol. 1, pp. 127–190

它求的是平滑后的参数目标，σ 既决定探索范围也改变平滑偏差[62]。

CMA-ES 进一步用选择结果及跨轮演化路径更新协方差和全局步长，使参数试验适应不同方向的尺度；并非仅把 CEM 的样本协方差换个名字[63]。

参数空间探索让一整段行为保持同一次参数扰动，可能形成时间一致的探索；每步动作噪声则在同一策略附近不断改变局部控制。前者不能免费绕过长时程困难：每组参数仍需足够回合才能辨认真实回报，高维全协方差要存储和估计二次数量的参数，排名还会被回报噪声改变。是否值得使用，应比较总真实交互、可并行程度、策略可微性和搜索维度，而不是只比较一次更新公式的长度。

[62] T. Salimans, J. Ho, X. Chen, S. Sidor, I. Sutskever, *Evolution Strategies as a Scalable Alternative to Reinforcement Learning*, 2017, arXiv: 1703.03864

[63] N. Hansen, A. Ostermeier, *Completely Derandomized Self-Adaptation in Evolution Strategies* In Evolutionary Computation, 2001, vol. 9, no. 2, pp. 159–195

3.4 基于模型的价值学习

回放可以重复使用记录，却不能直接回答某个未记录动作的后果。学习环境模型把已见经验拟合成可查询的后继和奖励预测器，用它补充价值更新或当前动作比较。本节保留两种使用方式：Dyna 生成模拟经验后更新动作价值；MPC 预测当前候选轨迹的回报，选出计划后只执行首动作。MPC 未必训练独立价值函数，但动作仍由预计回报比较产生。下一节才将模型用于训练跨状态共享的参数策略，让执行时直接调用该策略。

3.4.1 环境模型的表示与不确定性

在基准网格的 $(3,2)$ 执行向右，后继位置可能为 $(4,2)$、$(3,3)$ 或 $(3,1)$，概率分别是 $0.8, 0.1, 0.1$。若把坐标当连续量并最小化平方预测误差，最优输出是条件均值 $(3.8,2)$，但网格没有这个状态。平均位置既不能告诉规划器滑移会通往哪里，也不能直接代入只在合法格点上定义的价值函数。预测损失选错对象，甚至会使一个统计上正确的条件均值不适合控制。

定义 3.16　学习模型的预测对象　确定性动力学模型输出一个后继状态 $\widehat{f}_{\boldsymbol{\phi}}(s,a)$；随机动力学模型输出条件分布 $\widehat{P}_{\boldsymbol{\phi}}(\cdot \mid s,a)$。贝叶斯模型还在动力学参数或函数上保持后验 $p(\boldsymbol{\phi} \mid \mathcal{D})$，其后验预测需对该后验积分；集成模型则保留若干不同拟合的预测器，常由重采样数据和随机初始化获得。

动力学、奖励和终止是不同职责：$\widehat{P}$ 预测落点，$\widehat{R}(s,a)$ 预测即时奖励均值，$\widehat{c}(s,a,s')$ 预测转移后仍可继续的概率。也可联合学习 (s',r,c)，以保留其相关性。

这些预测量需要从真实记录中学习，而不是按控制回报直接拟合。令 $c_t=0$ 表示执行 a_t 后真正终止，$c_t=1$ 表示继续。对具备随机后继、条件

表示与实例	拟合和保留什么	控制接口与局限
显式状态模型	对位置、速度等已定义状态拟合后继分布；奖励可已知或另学	可直接将后继送入价值函数；坐标误差须结合状态尺度与决策后果解释
World Models	用 VAE 压缩图像，以混合密度递归模型预测潜在演化，控制器读取表示与记忆	控制器可用进化搜索训练；不同任务中模型承担表示或模拟器职责，不等于每步都做 MPC
PlaNet	确定递归分量与随机潜变量共同形成 RSSM；拟合观测、奖励及潜在多步关系	在潜在空间评估动作序列并执行首动作；搜索质量仍依赖模型滚动和状态推断

表 3.18　显式与潜在模型的区别。随机潜变量、参数后验和模型集成是不同层面的不确定性表示。

奖励和继续预测的模型，可以最小化记录中三个结果的负对数似然；期望按真实数据分布取，候选变量是模型参数 $\boldsymbol{\phi}$：

$$\mathbb{E}_{\mathcal{D}}\big[-\log \widehat{P}_{\boldsymbol{\phi}}(s_{t+1} \mid s_t, a_t) - \log p_{\boldsymbol{\phi}}(r_t \mid s_t, a_t, s_{t+1}) - \log p_{\boldsymbol{\phi}}(c_t \mid s_t, a_t, s_{t+1})\big].$$

训练时，将每条真实记录中的后继状态、奖励和继续标记分别送入三项负对数似然，更新模型参数。使用时，规划器给定 (s, a)，先抽取预测后继，再生成相应奖励和继续标记；若预测可以继续，就从该后继展开下一步，否则结束这条模拟轨迹。这样得到的轨迹可用于计算候选动作的预计回报。上述损失评价的是模型对记录的预测，策略目标则评价依这些预测选择动作后能取得多少回报。

生成联合样本时，还需明确三个预测之间的依赖。将上面三项对应的分布直接相乘，隐含了给定 (s, a, s') 后奖励与继续标记条件独立的假设；若不成立，应直接拟合它们的联合分布，或让继续预测再以奖励为条件。只计算期望回报的 Bellman 备份时，即时奖励的条件均值已经足够；要模拟风险或奖励与后继状态的联合事件，则需保留相应的分布与相关性。终止标签也必须来自任务本身：因采集上限中断的记录不能直接标成 $c_t = 0$，否则模型会把记录结束学成任务结束。

当观测是图像时，可先编码成潜在状态，再预测潜在后继。图3.15和表3.18拆开了这些部件。潜在模型沿用上述训练和使用过程，只是把显式状态换成内部表示，并可增加图像重建目标来训练编码器。

这一替换要求表示保留控制所需的信息。当前一帧看不出速度时，需要结合历史构造表示；单帧重建再准确也不能补回速度。RSSM 一类递归状态空间模型如何从历史形成状态，将在第4章处理。本节先考察模型如何使用给定表示，历史是否充分则由该章另行分析。

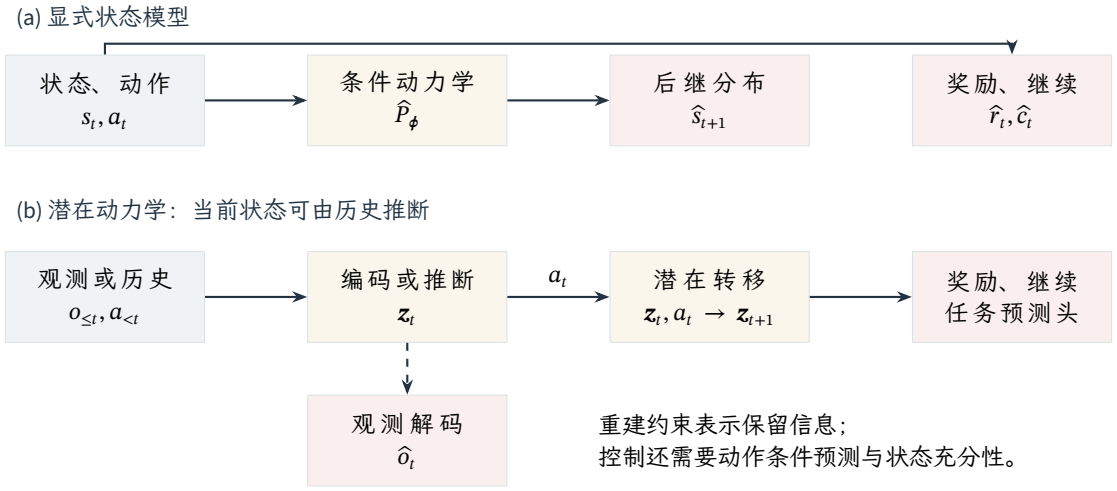


图 3.15 学习模型的预测职责。上排直接预测可观测状态，下排先形成潜在状态；解码重建、奖励与继续预测是不同输出，是否需要每个输出取决于下游用途。虚线表示可选的重建支路，不表示模型生成经验。

World Models 展示了压缩视觉、递归预测与小型控制器的组合[64]。PlaNet 进一步将潜在模型直接用于在线规划，二者所需的训练目标与执行成本并不相同[65]。

评价模型时至少要分清三件事。一步测试误差检查已有数据分布上的局部预测；多步闭环误差检查策略根据预测状态继续行动后的偏离；不确定性校准检查标成某个置信水平的集合是否具有相应覆盖率。一个只在远离门口处略有坐标误差的模型，可能控制得很好；另一个平均误差更小的模型，若恰好把门前可通行格预测成墙另一侧，就会改变最优动作。在连续化房间示例中，两条预测只相差很小距离也可能落在碰撞边界两侧，后果不能按平均像素距离比较。

集成分歧可以定位模型之间尚未达成一致的区域，但所有成员若共享训练缺口、特征缺陷或错误归纳偏置，也可能一致地错。只有另有统计假设和校准过程时，集成方差才能解释为某种置信半径；不能把“多个网络很一致”直接换成“真实环境一定如此”。

3.4.2 模型生成经验与价值更新

观察到通往终点的转移后，上游状态可能很久不再被访问，奖励信息却可以先通过已有模型传回去。Dyna 把真实经验更新和模型内规划接到同一 Q-learning 接口：先从真实样本学习，再抽取模型后果重复备份。对样本 (s, a, r, s', c)，无论其来源如何，更新均为

$$Q(s,a) \leftarrow Q(s,a) + \alpha \left[r + \gamma c \max_b Q(s',b) - Q(s,a) \right]. \tag{3.39}$$

[64] D. Ha, J. Schmidhuber, *Recurrent World Models Facilitate Policy Evolution* In Advances in Neural Information Processing Systems, 2018

[65] D. Hafner, T. Lillicrap, I. Fischer, R. Villegas, D. Ha, H. Lee, J. Davidson, *Learning Latent Dynamics for Planning from Pixels* In Proceedings of the 36th International Conference on Machine Learning, 2019, pp. 2555–2565

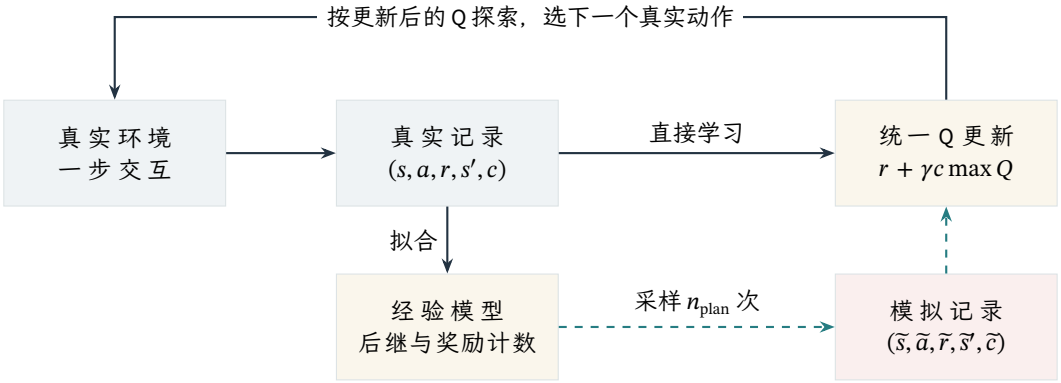


图 3.16 Dyna 的数据流。实线为真实交互及其记录，虚线为学习模型生成的经验；两者进入同一种 Q 更新。模型采样次数是规划计算量，不是新增真实交互量。

差别在于这条样本可能来自真实环境，也可能来自模型。图3.16用线型标出两类来源，算法3.4给出一个支持随机转移的表格版本。原始确定性 Dyna-Q 可以只记每个状态动作最后观察到的后果；随机网格应保存经验分布或学习一个能采样多种后果的模型[66]。

[66] R. S. Sutton, *Dyna, an Integrated Architecture for Learning, Planning, and Reacting* In SIGART Bulletin, 1991, vol. 2, no. 4, pp. 160–163

算法 3.4 随机表格 Dyna 的一轮交互

1: 在 s_t 按 Q 的探索策略选择 a_t，真实执行并记录 (r_t, s_{t+1}, c_t)。
2: 用式(3.39)更新真实访问的 $Q(s_t, a_t)$。
3: 更新该状态动作的后继、奖励及继续标记计数，形成经验联合模型。
4: **for** $i = 1, \dots, n_{\text{plan}}$ **do**
5: 　从已见状态动作中按指定规划分布选择 $(\tilde{s}, \tilde{a})$。
6: 　从当前经验模型采样 $(\tilde{r}, \tilde{s}', \tilde{c})$。
7: 　用同一 Q 更新式更新 $Q(\tilde{s}, \tilde{a})$。
8: **end for**
9: 若真正终止或达到环境的重置上限则重置；否则从 s_{t+1} 继续。仅时间截断时记录仍保留 $c_t = 1$ 及重置前的后继。

示例 3.17 不返回上游也能传播一次奖励 在基准网格中，假设此前记录过 $((3,2), \text{右}, -0.04, (4,2), 1)$，但当时所有 Q 值为 0。现在从 $(4,2)$ 向上恰好进入终点，用步长 1 把 $Q((4,2), \text{上})$ 更新为 1。若本轮模型从第一条记录生成相同转移，上游目标便为 $-0.04 + 0.9 \times 1 = 0.86$。从当前上游 Q 值 0 出发、取规划步长 0.5，一次模拟更新得到 0.43，无需真实返回 $(3,2)$。

这是单条经验模型的一次更新，不是随机网格的精确 Bellman 备份。若其他后继的最大 Q 值仍为 0，使用真实转移核的该次备份目标应为 $-0.04 + 0.9(0.8 \times 1) = 0.68$。模型中暂未记录的滑移不能因为多做模拟而消失。

对这条已经记录的转移，经验回放也能得到同样的 0.43。模型的额外能力不在于重复这条算术，而在于按概率组合后果、查询未记录但可泛化到的动作，或递归生成新状态。表3.19因此把数据复用与模型泛化分开。优先扫描还可按价值变化沿模型中的前驱关系分配规划次数；这种计算调度可以加快信息传播，但不能修正从未取得的真实转移信息。

经验来源	可重用或生成什么	额外风险
经验回放	原始记录中的完整转移	覆盖不足、旧策略分布与相关性
经验表格模型	已见状态动作的估计后果，可求期望或采样	有限计数误差，多次采样不增加原始信息
参数化模型	在新的状态动作处预测，并递归滚动	分布外泛化、终止错误及虚构可达状态

表 3.19 真实记录与生成经验。更灵活的查询接口同时引入了更强的模型正确性要求。

Dyna 增加多次分别采样的一步备份；也可以把连续几步预测合成当前状态的一次目标。这称为**模型价值扩展**（model-based value expansion, MVE）：短段奖励由模型预测，余下未来交给末端评论家。从真实回放状态 $\tilde{s}_0 = s$ 出发，按待评价策略和学习模型滚动 L 步；令 $\tilde{c}_j$ 为继续标记，$w_0 = 1$、$w_{j+1} = w_j \tilde{c}_j$，用累积继续权重屏蔽终止后的贡献，得到

$$\widehat{G}_0^{\mathrm{MVE}} = \sum_{j=0}^{L-1} \gamma^j w_j \tilde{r}_j + \gamma^L w_L V_{\bar{\boldsymbol{w}}}(\tilde{s}_L). \tag{3.40}$$

奖励、后继和继续标记来自模型，起点来自真实数据，末端价值来自目标评论家。若预测的是联合期望，应对联合滚动取期望；不能在存在相关性时任意用各自边缘均值的乘积替代。以动作价值为目标时，第一步固定待更新动作，后续才由评价策略选动作。评论家把 $\widehat{G}_0^{\mathrm{MVE}}$ 视为停止求导的目标，不在这一步沿模型反向优化策略[67]。

若模型完全正确且没有终止，末端评论家的统一误差 ϵ_V 只贡献 $\gamma^L \epsilon_V$。增大 L 会衰减这项，却增加了需要正确预测的奖励和状态数。例如一个独立教学滚动有 $L = 2$、预测奖励 $(0.1, 0.2)$、末端价值 0.5，则目标为 $0.1 + 0.9(0.2) + 0.9^2(0.5) = 0.685$；若第二步错误预测为终止，就丢失 0.405 的末端贡献。滚动更长不是单向改善，也不能把生成一百万条轨迹解释为获得了一百万条独立真实证据。

1803.00101

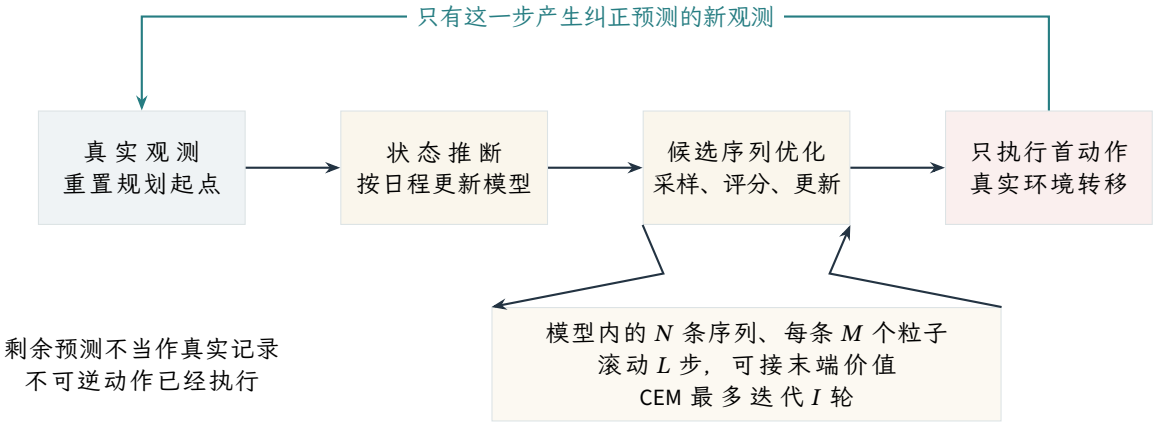


图 3.17 学习模型上的滚动规划。每轮用真实观测重新建立规划起点；模型拟合可以较低频率进行。当前优化结束后只执行首动作，预测轨迹的其余部分不会当作真实记录写回。

3.4.3 学习模型上的预测控制

在当前状态，模型也可以直接比较候选计划，不必先将结果写进长期 Q 表。本节沿用第2.4.2节的闭环：优化计划，只执行首动作，再用新观测重新规划。新增条件是动力学来自数据；为控制计算量，每轮优化还限制为预先给定的开环动作序列。若不同随机后继需要不同后续动作，一条固定序列不能表示这种反馈选择，即使模型准确也有限制。因此，前章针对反馈决策树的前瞻保证不能直接移用。图3.17标明真实纠正发生在哪里：环境只反馈已执行动作，不会验证本轮所有候选轨迹。

以有界连续动作 $\boldsymbol{u}_j \in [\boldsymbol{u}_{\min}, \boldsymbol{u}_{\max}]$ 为例，候选集合是长度 L 的合法动作序列。每条序列在模型中生成 M 个随机粒子轨迹，用平均预测奖励加末端价值估计期望回报，再选择评分较高的序列。评分为

$$\hat{F}(\boldsymbol{u}_{0:L-1}; s) = \frac{1}{M} \sum_{m=1}^{M} \left[\sum_{j=0}^{L-1} \gamma^j \hat{r}_j^{(m)} + \gamma^L \hat{V}(\hat{s}_L^{(m)}) \right]. \tag{3.41}$$

每个粒子从同一当前状态或其推断分布出发，经模型采样传播；终止时停止奖励并去掉末端价值。PETS 使用概率动力学集成和轨迹粒子传播：模型内输出的噪声刻画随机后继，不同集成成员的预测差异反映模型拟合的不一致。其 TS1 传播可在每一步重选模型成员，TS∞ 则让一个粒子在整个候选轨迹上保持同一成员；后者保留了“同一套动力学解释”在时间上的相关性，二者并不是同一个联合预测分布[68]。

表3.20比较三种轨迹优化器。CEM 在这里搜索的是本轮动作序列，不是前文跨状态共享的策略参数。一个可复现的教学配置为 $L = 5$、每轮 $N = 200$ 条候选、每条 $M = 20$ 个粒子、保留 $E = 20$ 条精英、最多 $I = 5$ 轮。初始化独立各维高斯，均值取上一步最优序列左移后的热启动，最后一步补零，标准差取动作范围的一半；第一轮没有历史序列时全取零均值。

[68] K. Chua, R. Calandra, R. McAllister, S. Levine, *Deep Reinforcement Learning in a Handful of Trials Using Probabilistic Dynamics Models* In Advances in Neural Information Processing Systems, 2018

优化器	候选和更新机制	信息需求与预算
随机 shooting	从固定提议分布抽序列，选择预计回报最高者	无梯度；一次评估 N 条，不利用精英改变下一轮分布
CEM	反复采样，截取精英，对序列分布重新做最大似然拟合	无梯度；需报告轮数、精英比例、方差下限及约束处理
MPPI	对名义序列加入噪声，用指数回报或负成本权重平均扰动	标准路径积分推导有动力学与噪声匹配条件；通用采样实现需说明重要性校正与控制代价

表 3.20 同一模型目标的不同优化接口。PETS 和 PlaNet 是模型与规划器的组合，不能与 CEM 这样的优化器放在互斥层级。

每轮从当前高斯采样并逐坐标裁剪到动作区间，按式(3.41)评分，取最高 E 条；并列按候选编号决定。用精英的逐坐标均值 $\boldsymbol{m}_{\mathcal{E}}$ 和方差 $\boldsymbol{v}_{\mathcal{E}}$ 更新

$$\boldsymbol{m} \leftarrow \tfrac{1}{2}\boldsymbol{m} + \tfrac{1}{2}\boldsymbol{m}_{\mathcal{E}}, \qquad \boldsymbol{v} \leftarrow \max\{\boldsymbol{v}_{\min}, \tfrac{1}{2}\boldsymbol{v} + \tfrac{1}{2}\boldsymbol{v}_{\mathcal{E}}\},$$

其中每个坐标的最小标准差预设为动作范围的 1%。此处“裁剪高斯”是具体实现选择，不冒充截断高斯的精确最大似然算法。完成 5 轮即停止，保留所有已评分候选中分数最高的一条，执行其首动作；不把未经重新评分的均值序列自动当成最佳候选。这样每个真实动作最多需要 $INML = 100\,000$ 次粒子转移调用，另加 INM 次末端价值调用。批量并行会改变耗时，但不改变这个查询计数。上述数字只用于明确预算，不是 PETS 的统一默认值。

MPPI 式加权常写为 $w_i \propto \exp((\widehat{F}_i - \max_j \widehat{F}_j)/\tau)$，再用 $\sum_i w_i \epsilon_i$ 修正名义序列；减去最大值只为数值稳定。如果采样分布不等于推导中的参考分布，或控制噪声结构改变，就须补相应权重，不能从这个指数形式单独推出路径积分最优控制结论[69]。

PlaNet 把候选动作送入潜在动力学，以预测奖励评估序列，使用 CEM 选择动作；它不需要为每个候选解码整段像素。PETS 则通常在给定状态坐标上预测动力学。两者都能闭环重规划，但预测对象、状态推断和每次查询成本不同。

墙边滑移说明重规划的边界。在基准网格的 $(4, 2)$ 向上，真实到达终点的概率是 0.8，还可能左滑至 $(3, 2)$ 或撞右墙原地不动。一个错误模型若把成功概率估为 0.98，短时域会高估立即结束的机会；过短时域且无末端价值又可能低估绕行，长时域则继续使用错误转移。下一次观测能告诉规划器这次是否滑移，却不能在动作执行前补回遗漏的风险。若把墙改成不可逆损失区域，重规划也无法撤销落入其中的动作；这种约束需要第8章的安全条件，而不是单靠“闭环”一词。

[69] G. Williams, A. Aldrich, E. A. Theodorou, *Model Predictive Path Integral Control: From Theory to Parallel Computation* In Journal of Guidance, Control, and Dynamics, 2017, vol. 40, no. 2, pp. 344–357

3.4.4 面向搜索的模型与表示

搜索比较向左和向右，直接需要的是各分支的奖励及长期价值，而非每个背景像素。若潜在模型在所用展开深度上保留这些预测量，并提供值得优先检查的动作，规划器就可能据此选择。MuZero 学习的正是服务于搜索的表示、动力学和预测头，不要求潜在状态还原完整观测；免去重建并没有免去决策相关预测的准确性要求[70]。

为避免与环境历史 h_t 混淆，记表示函数为 $e_{\boldsymbol{\phi}}$。从真实历史编码得到 $\boldsymbol{z}^0 = e_{\boldsymbol{\phi}}(h_t)$，潜在动力学与预测头为

$$(\hat{r}^k, \boldsymbol{z}^{k+1}) = g_{\boldsymbol{\phi}}(\boldsymbol{z}^k, a^k), \qquad (\boldsymbol{p}^k, \hat{v}^k) = f_{\boldsymbol{\phi}}(\boldsymbol{z}^k). \tag{3.42}$$

$\boldsymbol{p}^k$ 是动作先验，不是最终搜索访问分布；$\hat{v}^k$ 是叶值，不是从根开始的全部回报。沿搜索边备份时仍需加边上奖励：$G^k = \hat{r}^k + \gamma G^{k+1}$。如果一条新边预测奖励 -0.04、后继叶值 0.8，其返回值就是 0.68，不能把 0.8 原样抄回父节点。

搜索还需要分配有限展开次数，既检查当前返回值高的动作，也检查先验看好但尚少访问的动作。已展开节点存储访问数 $N(\boldsymbol{z}, a)$ 和平均返回值 $\overline{Q}(\boldsymbol{z}, a)$。在合法分支上最大化“返回值加探索项”，可用常数探索系数的 PUCT 形式说明：

$$a \in \arg\max_b \left[\overline{Q}(\boldsymbol{z}, b) + c\, p(b \mid \boldsymbol{z}) \frac{\sqrt{\sum_{b'} N(\boldsymbol{z}, b')}}{1 + N(\boldsymbol{z}, b)} \right].$$

实际 MuZero 还使用随访问数变化的系数、价值范围归一化和训练时根噪声等细节；应按任务实现保存配置。这一评分沿树选择到叶节点，调用一次潜在动力学生成新节点，查询预测头，再沿路径增加计数并更新均值。图3.18分开了搜索备份与训练监督。

例如人工搜索快照中根节点先已有向右 $N = 2, \overline{Q} = 0.85$，向上 $N = 1, \overline{Q} = 0.6$；一次新展开给向右返回 0.68，则其访问数变 3、均值变 $(2 \times 0.85 + 0.68)/3 \approx 0.7933$。若温度为 1，四次访问对应策略目标 $(3/4, 1/4)$；温度趋于 0 时则集中到访问数最大的动作。这里的访问来自搜索模拟，不是环境在同一状态真实走了四步。

搜索得到的访问统计随后也用于训练网络。我们从真实回放取起点和后续动作，按记录动作展开 K 步：奖励头拟合真实奖励，价值头拟合真实奖励加末端搜索价值，策略头拟合搜索访问分布。令 $\boldsymbol{\pi}_{t+k}^{\text{search}}$ 为该时刻保存

[70] J. Schrittwieser, I. Antonoglou, T. Hubert, K. Simonyan, L. Sifre, S. Schmitt, A. Guez, E. Lockhart, D. Hassabis, T. Graepel, T. Lillicrap, D. Silver, *Mastering Atari, Go, Chess and Shogi by Planning with a Learned Model* In Nature, 2020, vol. 588, pp. 604–609

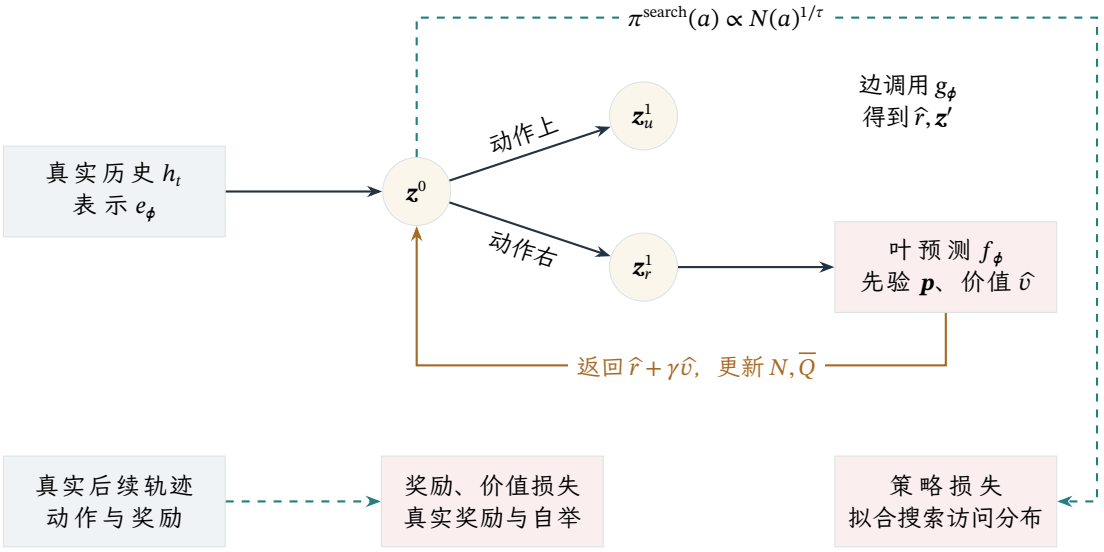


图 3.18 MuZero 的搜索与学习。上部在潜在状态中展开并把边奖励加上折扣叶值传回根；下部用真实轨迹训练奖励与价值预测，用搜索访问分布训练策略先验。潜在后继不是新观测，访问分布也不是真实动作频率的简单重放。

或重新计算的搜索策略目标，z_{t+k}^V 为相应 n 步价值目标；下面的损失在各展开位置累加，按三类误差最小化模型参数：

$$z_t^V = \sum_{j=0}^{n-1} \gamma^j r_{t+j} + \gamma^n v_{t+n}^{\text{search}},$$

$$L_{\text{MZ}} = \sum_{k=0}^{K} \left[\ell_v(\hat{v}^k, z_{t+k}^V) - \sum_a \pi_{t+k}^{\text{search}}(a) \log p_a^k \right] + \sum_{k=0}^{K-1} \ell_r(\hat{r}^k, r_{t+k}). \quad (3.43)$$

真实终止时截断奖励和自举；棋类可用最终胜负作为价值目标，Atari 等还会使用变换后的离散价值表示。式中 r_{t+k} 仍是执行记录动作 a_{t+k} 后的奖励，不能把潜在展开的第一个奖励错位一格。优化损失更新三个模块；下一批真实交互再用新模块搜索，形成“搜索改进策略目标、网络拟合搜索结果”的循环。

EfficientZero 针对有限真实数据补强这一循环：用记录后继的编码监督潜在展开的一致性，预测一段奖励的价值前缀以降低逐步奖励误差对备份的影响，并对旧数据的价值目标进行离策略修正和重新分析。以预测器 q 为例，一致性项可用 $-\cos(q(\hat{\boldsymbol{z}}^k), \text{sg}(e(o_{t+k})))$；停止梯度使目标分支不被当前一致性损失同步更新，但它本身不能排除表示塌缩；实际稳定性还依赖完整训练设计。它是在 MuZero 搜索学习接口上改进数据利用，不是“增加一个重建头”就自动取得相同样本效率[71]。

[71] W. Ye, S. Liu, T. Kurutach, P. Abbeel, Y. Gao, *Mastering Atari Games with Limited Data* In Advances in Neural Information Processing Systems, 2021

模型要求	直接训练或检查的对象	不能由此自动推出什么
可观测状态或图像重建	当前或未来可观测量的误差、似然	关键动作排序、未覆盖反事实及安全性
奖励、价值和策略预测	指定动作序列下的奖励、策略相关值及搜索分布	任意策略的回报、任意展开深度及完整环境规则
控制充分表示	在所需策略和干预集合上保留决策相关信息	超出这组策略、任务和干预后的继续有效性

表 3.21 重建与价值相关预测。要求应随模型实际承担的决策任务确定，不能按视觉精细程度排出统一优劣。

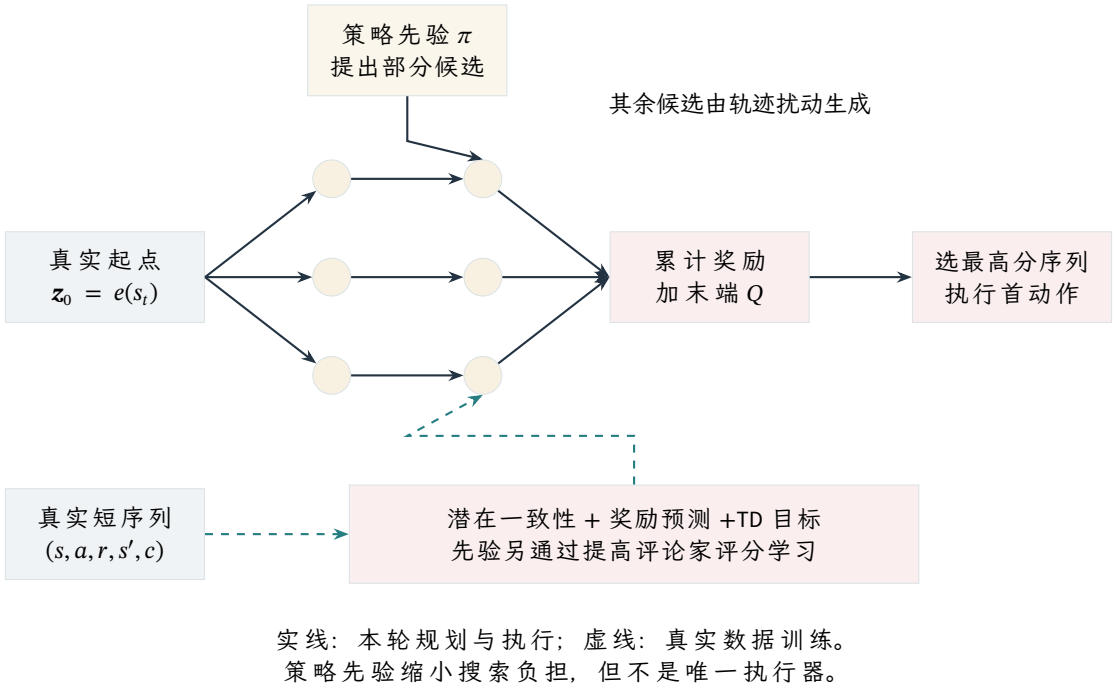


图 3.19 价值引导的潜在轨迹规划。多条轨迹共享真实起点，末端接评论家；策略先验生成一部分候选，规划评分决定本轮动作。下方训练路径拟合模型、奖励和 TD 目标，不等于执行时直接调用先验。

表3.21将两种要求对照。一个模型在行为策略轨迹上准确预测价值，仍可能在很少训练过的动作组合和更深搜索中任意出错；因此“无需重建”免去的是一个输出要求，不是免去反事实检验。部署时 MuZero 仍主要依赖搜索访问统计选动作，单独取策略头最大值是另一个执行协议。

3.4.5 潜在轨迹规划与价值引导

MuZero 沿树分配离散分支的展开次数。连续动作下每个节点有无穷多候选，另一种接口是直接采样并优化短动作序列。TD-MPC 将潜在动力学与 TD 价值结合：模型预测短段奖励和状态，末端评论家估计长尾回报，策略先验提出部分候选以缩小搜索范围。图3.19分开提议与执行，因为即使先验参与学习，最终动作仍由本轮规划评分决定。

先从当前真实状态编码 $\boldsymbol{z}_0 = e_{\boldsymbol{\phi}}(s)$，再按候选动作预测 $\boldsymbol{z}_{j+1} = d_{\boldsymbol{\phi}}(\boldsymbol{z}_j, a_j)$。为了比较这些合法序列，评分累加前 L 步预测奖励，并在末端调用策略先验和评论家补上未展开部分：

$$\widehat{F}(a_{0:L-1}) = \sum_{j=0}^{L-1} \gamma^j R_{\boldsymbol{\phi}}(\boldsymbol{z}_j, a_j) + \gamma^L Q_{\boldsymbol{w}}(\boldsymbol{z}_L, \pi_{\boldsymbol{\theta}}(\boldsymbol{z}_L)).$$

上式先写规划片段内不终止的情形；有终止时，需像式(3.40)一样用继续标记屏蔽后续奖励和末端值。末端的 Q 已含末端动作的奖励，前面的和只到 $L-1$，从而没有重复计数。候选可以混合高斯扰动序列与策略先验滚动；按回报加权或选精英迭代优化后，只执行首动作。即使先验在训练中不断提高，最终动作也未必等于 $\pi_{\boldsymbol{\theta}}(\boldsymbol{z}_0)$。

真实短序列支持三类损失。用 sg 表示停止梯度，以单步标量形式说明其关系：

$$\begin{aligned} y_t &= r_t + \gamma c_t Q_{\bar{\boldsymbol{w}}}(\bar{\boldsymbol{z}}_{t+1}, \pi_{\boldsymbol{\theta}}(\bar{\boldsymbol{z}}_{t+1})), \\ \ell_t &= \lambda_z \| d_{\boldsymbol{\phi}}(\boldsymbol{z}_t, a_t) - \mathrm{sg}(\bar{\boldsymbol{z}}_{t+1}) \|_2^2 + \lambda_r (R_{\boldsymbol{\phi}}(\boldsymbol{z}_t, a_t) - r_t)^2 \\ &\quad + \lambda_Q (Q_{\boldsymbol{w}}(\boldsymbol{z}_t, a_t) - \mathrm{sg}(y_t))^2. \end{aligned} \tag{3.44}$$

$\bar{\boldsymbol{z}}_{t+1}$ 由目标编码器对真实后继编码；多步训练时，预测分支沿记录动作递归展开，并按深度加权这些损失[72]。策略先验通过提高 $Q(\boldsymbol{z}, \pi_{\boldsymbol{\theta}}(\boldsymbol{z}))$ 学习，优化它时需固定评论家参数；模型和价值训练则使用记录动作。目标网络、归一化、正则化及实际 Q 集合依具体版本而定，式(3.44)展示原始方法的核心接口，不是 TD-MPC2 全部实现细节。

TD-MPC2 继续使用短潜在规划和末端价值，但对潜在状态做 SimNorm 归一化，采用离散分布式奖励与价值预测、Q 集成和最大熵策略先验等设计来增强跨任务训练稳定性。若把向量分成多个小组，每组 softmax 后的分量非负且和为 1，SimNorm 便限制了潜在表示的尺度；这不等于获得了动力学误差的统计置信界。分布式目标改善不同奖励尺度的优化，Q 集成抑制部分过估计，也不能替代真实访问覆盖。

TD-MPC2 原论文报告 104 个在线任务、四类任务域，并另有多任务规模实验；其中 317M 参数、80 任务的设置不能当成所有对比方法统一使用的预算。其结果支持的是相应数据、模型和任务协议下的经验结论，不是“潜在规划必然优于树搜索”的一般排序[73]。

表3.22按模型查询而不是名称比较三种接口。在固定总查询数 B 下，N 条长度 L、每条 M 粒子的轨迹大致消耗 NLM 次转移查询；树搜索可能每次模拟只扩展一个新节点，但还需遍历已建路径和维护统计。神经网络批处理、动作维数和叶值计算成本都不同，查询数相同仍不等于墙钟时间相同。

[72] N. A. Hansen, H. Su, X. Wang, *Temporal Difference Learning for Model Predictive Control* In Proceedings of the 39th International Conference on Machine Learning, 2022, pp. 8387–8406

[73] N. Hansen, H. Su, X. Wang, *TD-MPC2: Scalable, Robust World Models for Continuous Control* In International Conference on Learning Representations, 2024

规划接口	主要查询模块	动作结构	预算分配
潜在树搜索	表示、动力学、奖励、策略先验、叶值	有限分支最直接；连续动作需额外候选机制	在重复访问的分支间分配展开，并复用树中统计
轨迹采样	动力学、奖励，可选末端价值	向量动作及显式约束便于联合采样	候选数、粒子数、时域和迭代轮数相互争用预算
价值引导短规划	潜在动力学、奖励、末端 Q、策略先验	常用于连续控制	用评论家替代长尾滚动，把查询用于短轨迹优化

表 3.22 相同模型查询预算下仍需区分的计算。价值引导是轨迹评估的组成方式，可以与不同采样优化器组合。

3.4.6 模型偏差与规划边界

验证集上的低平均误差未必保护规划动作，因为规划器查询模型的方式不是随机平均：它专门寻找预计回报最高的候选。当某个少覆盖分支被高估，增加搜索反而可能更稳定地找到它。这称为**模型利用偏差**（model exploitation），即优化器将预测错误当成可利用收益。图3.20与下面的两路线例子展示了这一选择过程。

示例 3.18 优化器选择了最乐观的错误 将网格局部改成两个可选路线的独立教学任务。安全路线的真实与预测回报都为 0.6；稀少访问的“捷径”进入终点的真实概率为 0.1，失败进入零回报吸收态，即真实回报 0.1。模型却把成功概率估为 0.9，于是预计回报 0.9 并反复选择捷径。若测试数据的 99% 来自安全路线，则按该分布计算的平均绝对回报误差仅为 $0.01 \times 0.8 = 0.008$，实际选择的动作却损失 0.5。增加规划候选数可以更稳定地选中这个错误最大值，并不会自动降低误差。

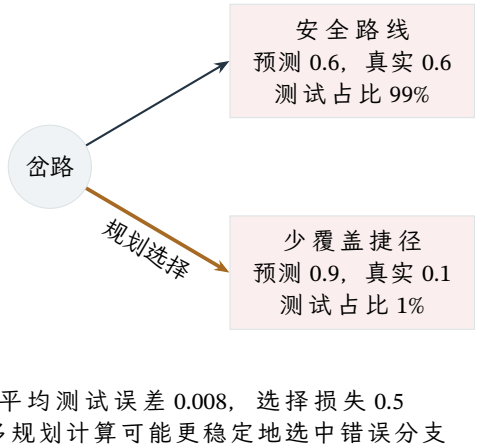


图 3.20 少覆盖分支上的模型利用偏差。数字属于例3.18的人工两路线任务；模型内最优动作与真实最优动作相反，测试分布的低平均误差掩盖了这一差别。

要把模型误差变成价值误差，需要说明误差在哪些状态动作上受控。下面给出一个统一但较强的条件；它不需要模型来自某种特定学习算法，也不会从经验损失小自动成立。

定理 3.19 固定策略的模型误差界 在相同有限状态动作空间、折扣 $0 \le \gamma < 1$ 上，两个 MDP 的奖励均值为 $R, \widehat{R}$、转移核为 $P, \widehat{P}$。假设两者奖励均值绝对值均不超过 $R_{\max}$，并且对每个合法 (s,a)，

$$|R(s,a) - \widehat{R}(s,a)| \le \varepsilon_R, \qquad \sum_{s'} |P(s' \mid s,a) - \widehat{P}(s' \mid s,a)| \le \varepsilon_P.$$

对任意固定平稳策略 π，记两个模型中的价值为 $V^\pi, \widehat{V}^\pi$，则

$$\|V^\pi - \widehat{V}^\pi\|_\infty \le B_{\text{model}} := \frac{\varepsilon_R}{1-\gamma} + \frac{\gamma R_{\max} \varepsilon_P}{(1-\gamma)^2}. \tag{3.45}$$

在相同初始分布下，$|J(\pi) - \widehat{J}(\pi)|$ 也不超过 B_{model}。

证明 对策略动作取平均后，奖励误差仍不超过 ε_R，每一行转移分布的 L^1 误差仍不超过 ε_P。由奖励界，$\|\widehat{V}^\pi\|_\infty \le R_{\max}/(1-\gamma)$。相减两个 Bellman 方程，并加减 $\gamma P^\pi \widehat{V}^\pi$，得到

$$V^\pi - \widehat{V}^\pi = R^\pi - \widehat{R}^\pi + \gamma P^\pi (V^\pi - \widehat{V}^\pi) + \gamma (P^\pi - \widehat{P}^\pi)\widehat{V}^\pi.$$

因 P^π 是随机矩阵，其中间项的无穷范数至多为 $\gamma \|V^\pi - \widehat{V}^\pi\|_\infty$。对末项逐行用三角不等式，

$$\|(P^\pi - \widehat{P}^\pi)\widehat{V}^\pi\|_\infty \le \varepsilon_P \|\widehat{V}^\pi\|_\infty \le \frac{R_{\max}\varepsilon_P}{1-\gamma}.$$

合并三项并把带 γ 的价值差移到左边，即得式(3.45)。最后对相同 ρ_0 取期望，概率加权平均不超过无穷范数，得到回报差结论。 ■

这种论证通常称为模拟引理的一个形式。这里 ε_P 是 L^1 误差；若用总变差 $\mathrm{TV} = \frac{1}{2}\|\cdot\|_1$ 定义误差，转移项系数必须相应改变，不能直接抄同一个常数。原始有限 MDP 学习分析中的模拟论证也是把局部模型误差传到长期回报，但具体时域与误差规范应按所引用结果区分[74]。

固定策略误差界还能支持模型内选出的策略，但需要误差条件统一覆盖候选所需的全部状态动作。设规划在学习模型的合法策略中最大化 $\widehat{J}$，输出 $\widehat{\pi}$ 的次优度至多 ϵ_{plan}。若上述统一误差事件成立，模型界就同时适用于

[74] M. Kearns, S. Singh, *Near-Optimal Reinforcement Learning in Polynomial Time* In Machine Learning, 2002, vol. 49, pp. 209–232

检验层次	它回答的问题	仍需补充的条件
重建质量	已观察内容能否编码并还原	决策相关量是否保留、历史是否充分
预测一致性	已覆盖动作序列的预测是否吻合	更长滚动、策略变化及误差校准
反事实正确性	换动作后模型是否仍有效	对所需干预的真实覆盖或可识别结构
控制充分性	用该表示和模型是否保持所需策略的决策质量	具体任务、策略类、规划深度与误差到性能的联系

表 3.23 模型质量不是一个无条件通用的分数。前一行通过并不自动保证后一行通过。

真实最优策略和依赖数据选出的 $\hat{\pi}$。将真实性能差拆成两侧模型误差和中间规划误差，得到

$$\begin{aligned} J(\pi^*) - J(\hat{\pi}) &= J(\pi^*) - \hat{J}(\pi^*) + \hat{J}(\pi^*) - \hat{J}(\hat{\pi}) + \hat{J}(\hat{\pi}) - J(\hat{\pi}) \\ &\le 2B_{\text{model}} + \epsilon_{\text{plan}}. \end{aligned}$$

中间项利用了 $\hat{J}(\pi^*) \le \max_\pi \hat{J}(\pi)$。若仅知道某个固定行为策略的模型误差小，第一和第三项不能同时这样控制，尤其不能把训练之后挑出的策略当成预先固定的策略。

表3.23归纳了检验层次。更精细的分析可以按占用分布加权误差，减少统一界的保守性，但要补上策略覆盖或分布转移的控制。重建误差、模型似然和集成分歧都可能是有用诊断量；它们各自需要通往决策目标的论证。基于模型置信集合的鲁棒优化与风险约束留到第8章。

3.5 基于模型的策略优化

当前规划只为这次状态求一个动作或动作序列，下次仍需重新搜索。若要训练一份可以跨状态重复调用的策略，优化变量就从本轮 $a_{0:L-1}$ 改成共享参数 θ。模型可以让回报梯度经过预测动力学传到策略，也可以生成经验供行动者—评论家训练。两者都将大量计算放在训练阶段，部署动作主要来自训练后的策略；但策略读取的状态仍可能需要模型依据新观测推断。

3.5.1 模型梯度与策略搜索

先考察模型如何提供真实环境无法直接给出的导数。在连续控制中，策略改变本步动作，动作改变后继状态，后继又改变下一次策略输出；求导需要保留整条依赖。设学到的动力学可重参数化为 $\boldsymbol{x}_{t+1} = f_{\boldsymbol{\phi}}(\boldsymbol{x}_t, \boldsymbol{u}_t, \boldsymbol{\xi}_t)$，策略为 $\boldsymbol{u}_t = \pi_\theta(\boldsymbol{x}_t)$，$\boldsymbol{\xi}_t$ 是分布与策略参数无关的随机噪声。固定模型参数 $\boldsymbol{\phi}$ 并对一条采样轨迹求导，记 $\boldsymbol{D}_t = \partial \boldsymbol{x}_t / \partial \theta$。由链式法则，

$$\boldsymbol{D}_{t+1} = (f_{\boldsymbol{x}} + f_{\boldsymbol{u}}\pi_{\boldsymbol{x}})\boldsymbol{D}_t + f_{\boldsymbol{u}}\pi_\theta, \qquad \boldsymbol{D}_0 = \boldsymbol{0}. \tag{3.46}$$

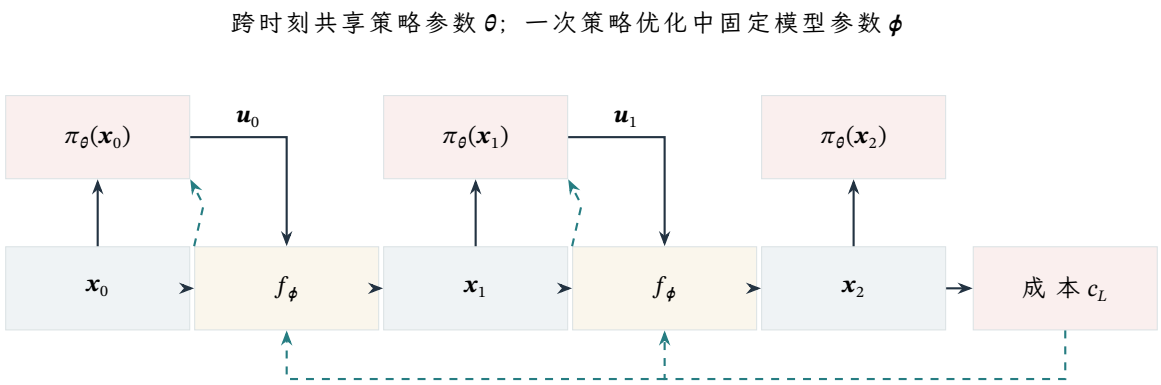


图 3.21 模型中的策略展开。每个时刻调用同一组策略参数，后继状态又进入策略；实线为前向依赖，虚线为策略优化时的反向导数。模型参数由真实数据更新，在一次策略梯度计算中固定，不因允许梯度穿过模型就同时最小化模型预测损失。

这里 $f_{\boldsymbol{x}}, f_{\boldsymbol{u}}$ 分别是动力学对状态、动作的 Jacobian，$\pi_{\boldsymbol{x}}, \pi_\theta$ 分别是策略对状态、参数的 Jacobian，均在当前滚动状态、动作和噪声上计算。第二项是本步参数直接改变动作的影响，第一项保留先前动作经状态传来的影响。把这些敏感度乘上成本导数，就能得到模型内策略的下降方向。若有限时域成本为 $C(\theta) = \mathbb{E}\sum_{t=0}^{L-1} c(\boldsymbol{x}_t, \boldsymbol{u}_t) + \mathbb{E}c_L(\boldsymbol{x}_L)$，则

$$\nabla_\theta C = \mathbb{E}\left[\sum_{t=0}^{L-1}\left(\boldsymbol{D}_t^\top \nabla_{\boldsymbol{x}} c_t + (\pi_{\boldsymbol{x}}\boldsymbol{D}_t + \pi_\theta)^\top \nabla_{\boldsymbol{u}} c_t\right) + \boldsymbol{D}_L^\top \nabla c_L(\boldsymbol{x}_L)\right].$$

这里成本越小越好，与本章奖励最大化的关系是 $r_t = -c_t$。将导数移入期望需要可微性和可积控制；接触、碰撞、离散动作及硬终止并不会自动满足这些条件。图3.21区分了训练模型与借模型训练策略的两条路径。

采样路径求导需要处理随机轨迹；另一种方式是直接传播状态分布的近似参数。PILCO 使用高斯过程描述动力学增量，同时保留给定数据的均值预测和不确定性。给定近似高斯的状态分布与参数策略，它通过矩匹配，让近似分布的均值和协方差等于所算的后继矩，递推状态分布，再对期望长期成本求导。把分布参数合记为 $\boldsymbol{m}_t = (\boldsymbol{\mu}_t, \mathrm{vec}\,\boldsymbol{\Sigma}_t)$，递推写成 $\boldsymbol{m}_{t+1} = F_\phi(\boldsymbol{m}_t, \theta)$，则

$$\frac{\partial \boldsymbol{m}_{t+1}}{\partial \theta} = \frac{\partial F_\phi}{\partial \boldsymbol{m}_t}\frac{\partial \boldsymbol{m}_t}{\partial \theta} + \frac{\partial F_\phi}{\partial \theta}.$$

期望成本 $\bar{c}(\boldsymbol{m}_t)$ 的导数再乘这些敏感度。高斯近似使计算可行，却可能丢失多峰分布；高斯过程后验不确定性也依赖核和噪声假设。这个过程不是对真实非线性轨迹分布的精确积分[75]。

[75] M. P. Deisenroth, C. E. Rasmussen, *PILCO: A Model-Based and Data-Efficient Approach to Policy Search* In Proceedings of the 28th International Conference on Machine Learning, 2011, pp. 465–472

接口	需要模型提供什么	主要计算与误差来源
采样路径反向传播	可微转移、奖励和策略；噪声可重参数化或另作梯度估计	保存或重算长度 L 的展开，导数连乘可能消失或爆炸；采样方差与模型导数偏差
分布传播的解析近似	可计算的分布矩、期望成本及其导数	传播均值和协方差；对分布形状、核和成本形式有要求，矩近似引入偏差
黑盒策略搜索	候选参数对应的模型回报样本	多候选、多噪声重复评分；不需模型 Jacobian，仍会利用错误的回报排序

表 3.24 模型参与策略搜索的三种方式。可微性减少了部分搜索成本，但给模型增加了导数质量要求。

示例 3.20 两步模型梯度 将连续控制简化为无噪声标量系统 $x_{t+1} = ax_t + bu_t$，$u_t = \theta x_t$，固定 $x_0 = 1$，仅有末端成本 $C = x_2^2/2$。记 $q = a + b\theta$，则 $x_1 = q$、$x_2 = q^2$，所以

$$\frac{\partial x_1}{\partial \theta} = b, \qquad \frac{\partial x_2}{\partial \theta} = qb + bx_1 = 2bq, \qquad \frac{\partial C}{\partial \theta} = 2bq^3.$$

人工取 $a = b = 1, \theta = -0.5$，梯度为 0.25；学习率 0.1 的一次成本下降更新给 $\theta' = -0.525$。若漏掉 x_1 进入第二次策略调用的导数，就会漏掉一半的梯度。

模型也可作为黑盒评分器。固定 θ，用它在模型里产生完整行为，再以采样回报驱动第3.3.6节的搜索；这不要求动力学可微，但需要更多候选评估。表3.24对比三种信息需求。

预测误差小和导数准确是两件事。例如真实一步模型 $f(u) = u$，近似模型 $\hat{f}(u) = u + \epsilon \sin(\omega u)$，全域预测误差不超过 ϵ，而导数误差为 $\epsilon\omega \cos(\omega u)$，可随 ω 任意增大。在 $u = 0$ 两者输出甚至完全相同。前节的价值误差界控制函数值，不控制这个导数；借模型求梯度还应检查策略会用到的局部敏感度，或用真实数据检验更新是否确实改进。

3.5.2 想象轨迹中的行动者—评论家

模型不必只提供导数，也可以在昂贵真实交互之间反复产生策略训练轨迹。World Models 将观测编码为潜在变量，用循环模型预测后继，并在模型内搜索控制器参数。Dreamer 则将这个训练环境接到行动者—评论家：策略在模型中行动，评论家评价预测回报，行动者再根据评价改进。这样复用的是学习到的预测规律，而不是新增真实证据[76]。

定义 3.21 想象轨迹 从真实历史推断的潜在状态出发，后续动作由策略产生、状态由学习模型生成、奖励与继续概率由预测头给出的序列，称为想象轨迹。起点使用真实观测的后验；离开起点后若没有新观测，后继来自模型先验，而非未来真实观测的编码。

[76] D. Ha, J. Schmidhuber, *Recurrent World Models Facilitate Policy Evolution* In Advances in Neural Information Processing Systems, 2018

要区分真实起点与想象后继，需要明确模型在有观测和无观测时怎样更新。循环状态空间模型（RSSM）用确定性记忆保存历史递推，用随机潜变量表示当前状态的条件不确定性。为避免与真实历史 h_t 混用，分别记为 $\boldsymbol{m}_t, \boldsymbol{z}_t$，合状态为 $\boldsymbol{x}_t = (\boldsymbol{m}_t, \boldsymbol{z}_t)$。真实序列用观测更新后验；想象时没有新观测，只能从先验预测前进。本节统一使用动作时刻的奖励索引：

$$\begin{aligned} \boldsymbol{m}_{t+1} &= f_{\boldsymbol{\phi}}(\boldsymbol{m}_t, \boldsymbol{z}_t, a_t), \\ q_{\boldsymbol{\phi}}(\boldsymbol{z}_{t+1} \mid \boldsymbol{m}_{t+1}, o_{t+1}) &\quad \text{用于真实观测序列的后验推断}, \\ p_{\boldsymbol{\phi}}(\boldsymbol{z}_{t+1} \mid \boldsymbol{m}_{t+1}) &\quad \text{用于无后续观测的先验滚动}. \end{aligned} \tag{3.47}$$

奖励 r_t 及是否继续 c_t 的预测可在该转移的后继潜在状态上读出。若实现把进入状态时的奖励记作 r_{t+1}，只须整体对齐索引，不能把旧观测之后、动作之前的奖励混进同一个目标。

真实序列中的观测、奖励和继续变量提供预测监督，但只有这三项还不足以训练无观测滚动：模型还需使先验接近带观测的后验。以 DreamerV3 的离散潜变量为例，记 q_t, p_t 为同一时刻的后验、先验。下面先累加三类负对数似然，再用分别停止一侧梯度的 KL 项训练先验和表示；模型参数最小化其真实序列期望：

$$\begin{aligned} \ell_{\text{pred},t} &= -\log p_{\boldsymbol{\phi}}(o_t \mid \boldsymbol{x}_t) - \log p_{\boldsymbol{\phi}}(r_{t-1} \mid \boldsymbol{x}_t) - \log p_{\boldsymbol{\phi}}(c_{t-1} \mid \boldsymbol{x}_t), \\ \ell_{\text{dyn},t} &= \max\{1, D_{\mathrm{KL}}(\operatorname{sg}(q_t) \| p_t)\}, \\ \ell_{\text{rep},t} &= \max\{1, D_{\mathrm{KL}}(q_t \| \operatorname{sg}(p_t))\}, \\ L_{\text{model}} &= \mathbb{E} \sum_t [\ell_{\text{pred},t} + \ell_{\text{dyn},t} + 0.1 \ell_{\text{rep},t}]. \end{aligned} \tag{3.48}$$

序列首项没有对应转移监督时省去奖励和继续损失。这里 r_{t-1} 明确指进入 $\boldsymbol{x}_t$ 的上一步奖励，并未改动本章的经验定义。两项 KL 分别调整先验和表示，低于 1 nat 的部分不再施加 KL 压力；实际离散分布还混入 1% 均匀概率以避免极端概率。观测重建帮助训练表示，但不能单独证明其对所有控制干预充分。

模型固定后，行动者和评论家需要一个不再依赖未来真实奖励的训练目标。我们从真实后验状态 $\hat{\boldsymbol{x}}_0$ 开始想象，采样 $\hat{a}_j \sim \pi_{\boldsymbol{\theta}}(\cdot \mid \hat{\boldsymbol{x}}_j)$，再依次得到 $\hat{\boldsymbol{x}}_{j+1}, \hat{r}_j, \hat{c}_j$。记 $\hat{\gamma}_j = \gamma \hat{c}_j$ 为单步有效折扣，长度 L 的 λ 回报按逆序递推：

$$\widehat{G}_L^{\lambda} = v_{\boldsymbol{w}}(\hat{\boldsymbol{x}}_L), \qquad \widehat{G}_j^{\lambda} = \hat{r}_j + \hat{\gamma}_j [(1-\lambda) v_{\boldsymbol{w}}(\hat{\boldsymbol{x}}_{j+1}) + \lambda \widehat{G}_{j+1}^{\lambda}]. \tag{3.49}$$

例如教学设定 $\gamma = 0.9, \lambda = 0.5, L = 2$，两次继续概率均为 1，奖励为 $(0.2, 0.3)$，后继价值为 $(0.4, 0.6)$。于是 $\widehat{G}_1^{\lambda} = 0.84$，$\widehat{G}_0^{\lambda} = 0.758$。若第二步继续概率改成 0，则相应两值为 0.3 和 0.515。这说明继续预测错误会同时污染回报与轨迹的有效权重。

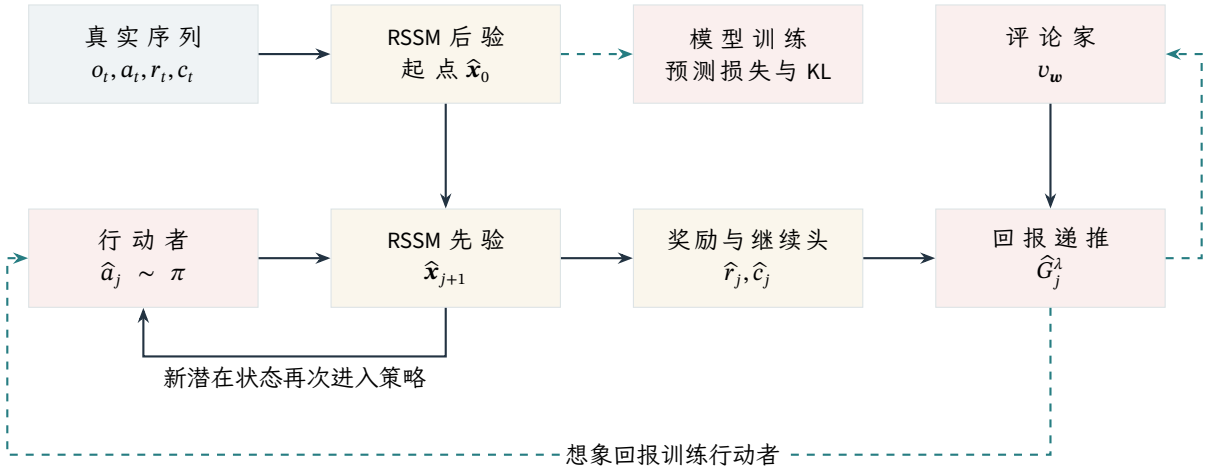


图 3.22 RSSM 上的真实学习与想象学习。真实序列经后验形成起点并训练世界模型；想象轨迹由先验前进，奖励和继续概率进入回报，价值给出末端自举。部署仍需用新观测更新模型状态，不能把“无逐步搜索”理解为“不再调用模型”。

Dreamer 各版本使用同一训练分工，但不是同一损失。最初版本用连续随机潜变量，并在连续控制中通过模型和评论家反向传播想象回报来训练行动者。DreamerV2 改用离散潜变量和直通估计，行动者结合路径导数与似然比估计的方式依动作类型、配置而异[77]。

V2 的变化使离散视觉控制中的想象学习更实用，但不能据此把后续 V3 的纯似然比行动者写成相同梯度。V2 的网络、目标与评估协议应按其独立论文理解[78]。

V3 还需处理不同任务的奖励尺度。本书采用 2025 年 Nature 正式版的表示：奖励和价值输出固定支撑上的离散概率，而不是直接回归一个标量。取 $b_i = \operatorname{symexp}(u_i)$，$\operatorname{symexp}(u) = \operatorname{sign}(u)(e^{|u|} - 1)$，$u_i$ 在 $[-20, 20]$ 上等距。若目标 y 位于 b_i, b_{i+1} 之间，two-hot 目标把概率 $(b_{i+1} - y)/(b_{i+1} - b_i)$ 和 $(y - b_i)/(b_{i+1} - b_i)$ 放在相邻两点，其他为 0；超出支持范围的值截到边界。训练用该目标与预测分布的交叉熵，读出的均值是 $\sum_i p_i b_i$。它是在原始值域插值，不是“先在 symlog 域求均值，再反变换”的旧式概括。

two-hot 编码将目标夹在相邻两点之间的距离转成两个概率，避免只指定最近的一个支撑点。用 $\mathcal{T}(y)$ 记这一编码，评论家通过最小化它与预测分布的交叉熵拟合停止求导的想象回报，主要项为

$$\ell_{\text{critic},j} = -\sum_i \mathcal{T}_i(\operatorname{sg} \hat{G}_j^{\lambda}) \log p_{\boldsymbol{w},i}(\hat{\boldsymbol{x}}_j).$$

这里对软目标取交叉熵。正式版还用 EMA 评论家输出作正则，并加入真实回放上的辅助价值损失，权重为 0.3；真实序列的目标利用对应想象起

[77] D. Hafner, T. Lillicrap, J. Ba, M. Norouzi, *Dream to Control: Learning Behaviors by Latent Imagination* In International Conference on Learning Representations, 2020

[78] D. Hafner, T. Lillicrap, M. Norouzi, J. Ba, *Mastering Atari with Discrete World Models* In International Conference on Learning Representations, 2021

阶段	模型及策略调用	不能省略的成本或检验
真实序列训练	编码观测、后验推断、重建及预测头，梯度更新模型	真实数据数量、序列长度与反向传播内存
想象训练	多起点先验滚动，逐步调用行动者、奖励、继续与价值头	模型转移数、评论家和行动者更新数；高模型回报需真实评估
部署执行	更新循环记忆和观测后验，从策略采样或取约定动作	每步状态推断仍有模型成本；随机或确定性评估须预先固定
在线再学习	将新经验写回回放并交替更新三个模块	是否允许继续交互、何时更新及更新后状态重算

表 3.25 想象学习没有消除模型计算，而是改变了计算发生的位置。部署不做候选轨迹搜索，也不等于一个无状态的策略网络即可运行。

点的在策略回报作标注。这不同于把所有回报自举值统一替换为 EMA 目标网络。式(3.49)明确使用当前评论家，监督目标一侧停止梯度。

评论家拟合预测回报后，V3 用回报减价值形成行动者优势，并对离散和连续动作均采用归一化的 REINFORCE，而非让梯度直接穿过想象动力学。记 $W_j = \prod_{i<j} \hat{\gamma}_i$，$S$ 为想象回报第 95 与第 5 百分位差的指数移动平均，则其最大化目标的采样形式为

$$\sum_{j=0}^{L-1} W_j \left[\log \pi_\theta(\hat{a}_j \mid \hat{\boldsymbol{x}}_j) \operatorname{sg}\left(\frac{\hat{G}_j^\lambda - v_{\boldsymbol{w}}(\hat{\boldsymbol{x}}_j)}{\max(1, S)} \right) + \eta \, \mathcal{H}(\pi_\theta(\cdot \mid \hat{\boldsymbol{x}}_j)) \right]. \tag{3.50}$$

状态、权重和优势在这次行动者更新中作为采样量固定，熵项鼓励而不是惩罚随机性。它从回放起点训练有限想象片段，是实际优化代理，不应声称未经校正就等于真实初始分布目标 J 的精确梯度；因此这里也没有用未归一化的采样和冒充归一化占用期望。

V3 正式论文报告多个控制基准上的实验，多数基准使用 5 个训练种子；Minecraft 与 BSuite 使用 10 个。Minecraft 实验的动作包含抽象合成命令，且有加速破坏方块等协议约定。算法的真实环境证据应连同这些条件解读，不能只把“获得钻石”四字当成跨接口可比的性能单位[79]。

表3.25说明训练和部署的差别。图3.22中的后验是观测历史的压缩推断，其何时能充当决策状态留给第4章；本章先把它作为算法实际使用的状态输入。

[79] D. Hafner, J. Pasukonis, J. Ba, T. Lillicrap, *Mastering Diverse Control Tasks through World Models* In Nature, 2025, vol. 640, no. 8059, pp. 647–653

3.5.3 短模型滚动与离策略优化

长想象轨迹反复使用模型，错误状态可能继续影响后续奖励和策略输入。MBPO 选择另一种折中：从真实回放状态分支，只生成几步经验，写入独立模型缓冲，再混合两类数据训练 SAC。它不在这段动力学上直接反传行动者梯度。生成经验的部件与第3.4.2节相同，主要改进对象却是显式行动者；MVE 则将短滚动合成一次价值目标，三者不能仅因都用了模型样本就视为相同更新。

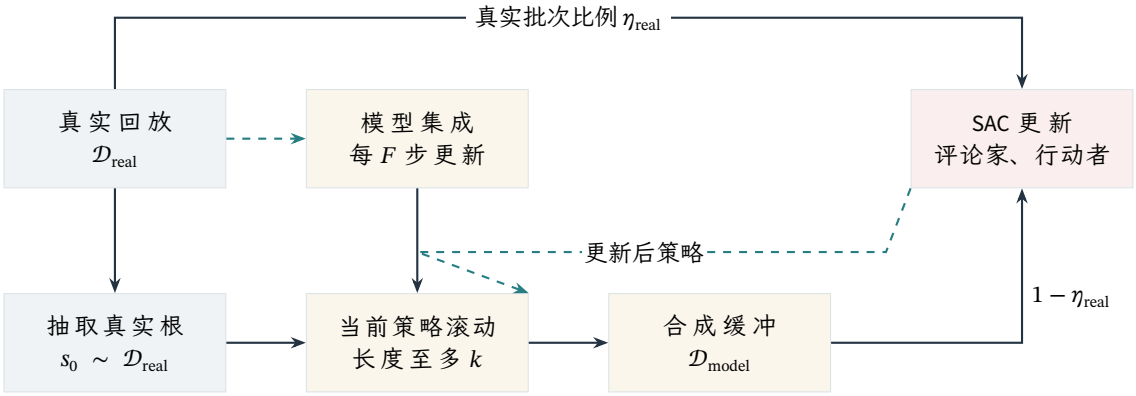


图 3.23 MBPO 的短分支经验。分支根来自真实回放，根之后的状态、奖励和终止由模型给出；合成缓冲与真实缓冲共同训练 SAC。行动者优化时不需要沿动力学反向传播，模型学习仍只以真实数据为监督来源。

记真实缓冲为 $\mathcal{D}_{\text{real}}$、合成缓冲为 $\mathcal{D}_{\text{model}}$；每隔 F 个真实环境步拟合一次概率模型集成，每轮抽 B 个真实起点，按当前策略生成至多 k 步。训练批次中真实经验比例为 η_{real}，其余来自合成缓冲。$F, k, B, \eta_{\text{real}}$ 以及模型数据保留多久，都影响旧模型和旧策略样本的占比，必须写入配置。图3.23保留了两条数据来源。

一次合成转移可追溯为：从真实记录抽 $s = (3,1)$，当前行动者抽到向上，某个集成成员抽到后继 $(3,2)$ 并预测奖励 -0.04、非终止，于是把 $((3,1), \text{上}, -0.04, (3,2), 1)$ 及模型版本写入模型缓冲。这一转移在基准网格中可能发生，但本次并没有真的执行；其采样概率取决于所选模型。设后继的 SAC 目标软值为 0.5，则这条经验给出的评论家目标是 $-0.04 + 0.9 \times 0.5 = 0.41$。随后行动者在混合批次的状态上最小化 $\mathbb{E}[\alpha \log \pi_\theta(a \mid s) - \min_i Q_{\boldsymbol{w}_i}(s,a)]$。这一更新不能因为根是真实状态，就把后继也当成真实观测。

缩短滚动直接减少连续使用错误转移的次数，但也更依赖末端价值。为了量化这项取舍，我们先比较同一起点分布、同一固定策略在真实与学习模型中的 k 步自举评分。设两种分支从 ν 出发，深度 j 的真实状态动作分布为 q_j^π；以总变差度量后继分布误差，以绝对值度量奖励均值误差，记

$$e_P(s,a) = \mathrm{TV}(P(\cdot \mid s,a), \widehat{P}(\cdot \mid s,a)), \qquad e_R(s,a) = |R(s,a) - \widehat{R}(s,a)|.$$

假设每个 $j < k$ 都有 $\mathbb{E}_{q_j^\pi} e_P \le \epsilon_m$、$\mathbb{E}_{q_j^\pi} e_R \le \epsilon_r$，两模型奖励均值绝对值不超过 $R_{\max}$，并用同一个末端函数 V 且 $\|V\|_\infty \le V_{\max}$。逐步使用概率核的

设计	直接作用	仍未保证的条件
从真实回放分支	避免从模型生成的长历史起步	根可能来自旧策略；根之后仍会偏离真实覆盖
限制 k 并调整日程	减少连续使用错误转移的次数	不证明末端价值准确，也不证明给定长度最优
提高真实批次比例	减少当前更新中合成数据的权重	不能补出真实数据未访问的动作
集成分歧筛选	排除模型成员明显不一致的转移	成员可能共同犯错；分歧不是经校准的 TV 半径
限制模型数据寿命	降低旧模型生成经验的占比	当前模型仍可能有系统性偏差

表 3.26 短模型滚动的控制量与边界。它们是需要验证的算法设计，不是全局性能或安全证明。

非扩张性，得到深度 j 的两种状态分布的总变差不超过 $j\epsilon_m$。于是两个 k 步自举评分相差至多

$$B_k = \sum_{j=0}^{k-1} \gamma^j (\epsilon_r + 2R_{\max} j\epsilon_m) + 2\gamma^k V_{\max} k\epsilon_m. \tag{3.51}$$

奖励误差被分为真实访问处的模型误差与两个访问分布的差，后者乘 $2R_{\max}$；末端项同理。若还要与真实无限回报比较，且 $\|V - V^\pi\|_\infty \le \epsilon_V$，须再加 $\gamma^k \epsilon_V$。短时域降低转移误差累积，却让末端价值误差衰减得更少，不能据此推出 k 越小永远越好。

这个界使用的是目标策略在各深度真实访问处的平均误差，验证数据却通常来自行为策略 μ。从 q_j^μ 转换到 q_j^π，需要知道新策略是否过度访问旧数据少见的区域。若有 $q_j^\pi(s,a) \le C_j q_j^\mu(s,a)$，则非负模型误差的期望至多放大 C_j 倍；只知道行为分布上的小均方误差，并不等于已知 ϵ_m，更不等于已控制 C_j。另一种思路是限制 $\sup_s \mathrm{TV}(\pi(\cdot \mid s), \mu(\cdot \mid s)) \le \epsilon_\pi$：从相同根分布出发，逐步耦合给出策略引起的轨迹分布偏离至多随深度线性增长。MBPO 的原始分析正是把数据策略下的模型总变差误差与策略变化结合，讨论短分支的改进下界；它的抽象单调改进条件不等于实际集成网络加 SAC 必然单调改进[80]。

若式(3.51)对整个候选策略集合同时成立，且模型内选择的策略对相应真实目标使用了误差受控的末端值，那么模型代理提升超过两侧总误差才支持真实提升。仅对更新前策略成立的平均验证误差不足以做此推断。表3.26列出常用限制各自约束了什么。

[80] M. Janner, J. Fu, M. Zhang, S. Levine, *When to Trust Your Model: Model-Based Policy Optimization* In Advances in Neural Information Processing Systems, 2019

3.5.4 模型误差下的策略优化边界

不做部署搜索并不能避免模型利用偏差，模型梯度同样会把行动者引向高估区域。设一个独立的一步连续动作教学任务为 $a \in [-1,1]$、真实奖励 $R(a) = -a^2$，模型奖励 $\widehat{R}(a) = -a^2 + 0.8a$。训练数据若只含 $a = 0$，模型在那里误差为 0；从确定性策略 $a = \theta = 0$ 出发，模型梯度却是 0.8。它最

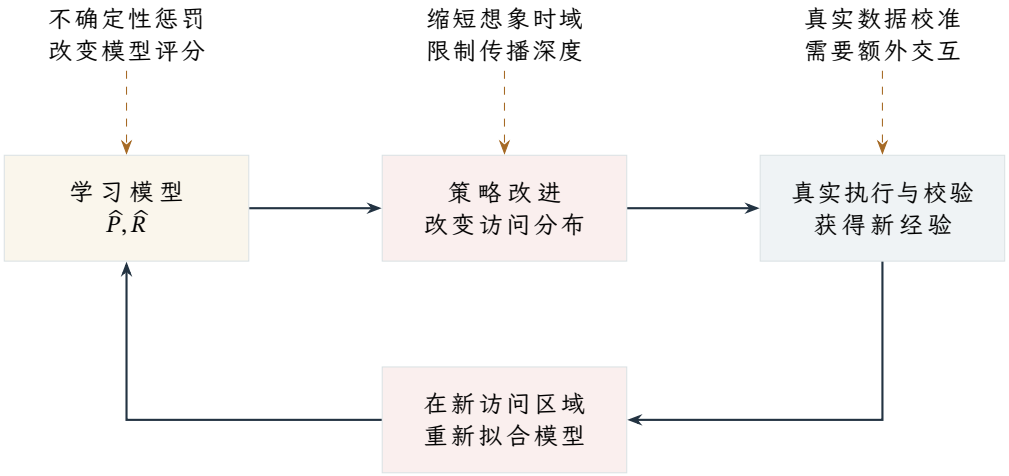


图 3.24 模型策略优化中的访问分布反馈。虚线标明三种限制分别作用的位置；补充真实数据要求仍有交互能力，离线训练不能假定这条边随时可用。上例中的模型梯度把策略从已验证的 $a = 0$ 推向未验证区域。

误差处置	主要限制的环节	代价及不足
不确定性惩罚	用 $\hat{R} - \lambda u$ 降低未确信区域的代理收益	需要 u 对相关错误敏感；可能过度保守、阻碍必要探索
缩短想象时域	减少模型误差传播深度	更依赖末端评论家，可能漏掉延迟后果
真实数据校准	在新策略访问处验证并更新模型	需要额外交互；不可逆损失不能靠事后校准撤销
限制策略变化	避免单次更新过快远离支持区域	局部变化小仍可累积成大偏离，旧覆盖不永久有效

表 3.27 模型误差措施并不互相替代。惩罚改变评分，短时域改变传播，真实校准改变信息；三者对应不同的误差来源。

终把动作推到 0.4，预测奖励 0.16，真实奖励 −0.16，而原策略真实奖励为 0。这个例子不涉及长时域误差，已经足以说明“多做模型内策略更新”可能降低真实性能。

上例的旧策略只访问 $a = 0$，模型评价该策略完全准确；优化却选出了旧数据从未验证的 $a = 0.4$。因此，从固定策略评估扩大到模型内选策略时，误差控制也要扩大到候选策略会到达的区域，或由能处理数据依赖选择的置信集合承担这一要求。第3.4.6节的统一模拟界可支持选择后的回报结论，单点拟合则不能。图3.24展示策略改变访问分布后需要补充真实验证的反馈，表3.27列出处置位置与代价。

动作条件视频模型将预测对象扩大到画面序列，但策略训练仍依赖动作后果是否正确。生成画面可以逼真，却错误地预测“按下这个键便到达门口”。判断其能否支持策略训练，需核对动作接口、数据是否覆盖所需干预、奖励和终止的来源、部署能否闭环接收观测，以及真实环境测试结果。开放环视频质量评价观测预测，不能单独继承为闭环回报保证。

Dreamer 4 提供了一个具体延伸案例。这里讨论的是 2025 年 9 月 29 日发布的原始预印本版本[81]。它使用 VPT 承包者提供的 2541 小时、360p、20 帧每秒的 Minecraft 视频及键鼠和事件记录；动作接口包含 23 个二元按键与 121 类鼠标动作。模型内学习使用任务嵌入，测试有预设任务提示序列。真实数据训练是离线的；即便模型内策略采样是同策略，也不意味着算法在真实环境中在线采集训练数据。

该版本报告在 1000 个随机世界、空背包、每回合 60 分钟的真实 Minecraft 测试中，获得钻石的成功率为 0.7%。这是闭环环境证据，强于只展示视频，却仍受动作接口、任务提示和数据来源限制；它既不是 DreamerV3 抽象动作协议下的直接同预算比较，也不是机器人安全保证。模型速度、生成质量和策略成功率应分开报告。

至此，模型的用途已能用信息流区分：Dyna 把模拟转移用于价值备份，MPC 与 MuZero 用模型进行当前决策搜索，Dreamer 把想象轨迹用于策略训练，MBPO 把短合成转移交给离策略行动者—评论家。一个系统可以同时拥有这些部件；判断其条件，应看真实数据如何进入、哪项预测参与了哪次更新，以及最终动作究竟由谁给出。

[81] D. Hafner, W. Yan, T. Lillicrap, *Training Agents Inside of Scalable World Models* In arXiv preprint arXiv:2509.24527, 2025

3.6 时间抽象下的价值与策略学习

前述更新默认每步选择一个原子动作。在房间导航中，一段“走到门口”的控制过程可以重复调用，高层不必每步重新选方向。时间抽象（temporal abstraction）把这段持续行为当作一次决策，改变的是决策间隔，而不是是否使用模型或是否优化显式策略。因此它可分别与四种求解组合结合，也仍需要学习内部动作、评价长期回报和取得覆盖数据。

3.6.1 时间抽象解决什么问题

为突出房间结构，本节另设一个完全可观测的确定性教学网格，不使用前文 4×3 基准的数值：格点为 $x=1,\dots,8$、$y=1,\dots,5$；$x=4$ 与 $x=5$ 之间有墙，仅在 $y=2,4$ 开门。上下左右每步确定移动一格，不合法动作不可选。起点为 $(2,2)$、目标为 $(7,2)$，入目标奖励 1，其余步 -0.04，$\gamma=0.9$。图3.25画出原子动作与高层决策的对应。

从起点到目标的最短路线仍需五个原子动作。若预先可调用两步的“到下门左侧 $(4,2)$”和三步的“穿下门并到目标”，高层只选择两次，执行层却仍与环境交互五步。时间抽象节省的是高层决策深度：在更大房间中，探索可以保持一段有方向的行为，回报也可评价整个子任务。要取得这些收益，内部控制必须能完成调用，终止规则必须在适当时刻交回控制权；两者本身也有学习代价。

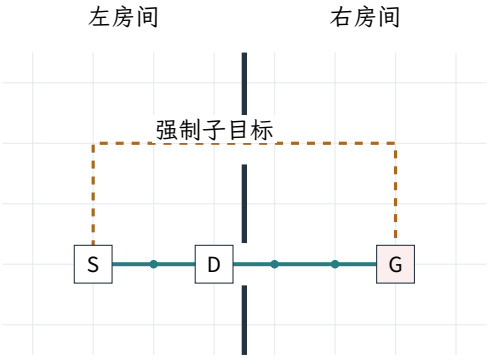


图 3.25 两房间教学网格中的时间抽象。实线路径有五个原子动作，可由两次高层调用组成；虚线路径强制经过上门左侧，多走四步。圆点表示原子时刻，方框标出高层选择时刻。所有几何与奖励规则均为本节独立教学设定。

职责	输入与输出	需要指定或学习的对象
高层选择	状态、任务 → 行为编号或子目标	高层策略、每个行为的价值及可启动条件
内部控制	当前状态、行为或子目标 → 原子动作	低层策略，必要时用子任务奖励训练
终止判定	当前状态、行为 → 是否交还控制	终止概率、超时或到达条件；超时不必等于环境终止

表 3.28 时间抽象的三个学习对象。手工规则与自动发现是获得这些对象的不同方式，不改变它们各自的职责。

动作的取值形式与持续时间是两个维度。机器人每毫秒选择一次实数力矩，虽是连续动作，仍是原子决策；“沿墙前进直到门口”可以只有一个离散编号，却持续随机多步。时间抽象本身不改变外在奖励目标，也不承诺内部执行满足安全约束。若为了训练低层另外奖励“接近门口”，还须说明这是辅助目标，以及它是否可能与全局目标冲突。

表3.28也指出为什么“给动作起一个高层名字”还不够：必须知道在何处可执行、执行期间如何行动、多久返回。只有这些条件明确，才能把一段行为当作新的动作参与备份。

3.6.2 半马尔可夫决策与 Options

调用“到门口”后，下一次高层决策可能在两步后，也可能因绕行在更晚发生。高层因此要同时记录终点、期间奖励和持续时间，不能继续把每次调用当成原来的一步动作。半马尔可夫决策保留这三种随机后果；Option 则用启动条件、内部动作策略和终止规则描述一个可调用行为。

定义 3.22 半马尔可夫决策与 Markov Option 若决策仅在随机时刻发生，一次动作同时决定下一决策状态、期间累计奖励和持续时间，其决策过程称为半马尔可夫决策过程。一个 Markov Option 记为 $\omega = (I_\omega, \pi_\omega, \beta_\omega)$：$I_\omega \subseteq \mathcal{S}$ 是启动集，$\pi_\omega(a \mid s)$ 是内部原子动作策略，$\beta_\omega(s) \in [0,1]$ 是在到达 s 后终止的概率。本节采用先执行至少一个原子动作、再检测终止的调用方式，且三者只依赖当前状态和 Option 编号。高层策略 $\zeta(\omega \mid s)$ 只在允许启动的 Option 中选择。

在固定内部策略和终止规则下，起点 s 与 Optionω 决定终点及持续时间的分布，这正是半马尔可夫模型。原子动作也可保留：令其内部只执行该动作一次并立即终止，即得到持续时间 $K = 1$ 的 Option。若 Option 依赖内部记忆或已执行时长，需把所需变量并入状态，不能继续无条件使用上述 Markov 形式。Options 框架将这种多步行为与原有 MDP 的价值学习连接起来[82]。

[82] R. S. Sutton, D. Precup, S. Singh, *Between MDPs and Semi-MDPs: A Framework for Temporal Abstraction in Reinforcement Learning* In Artificial Intelligence, 1999, vol. 112, no. 1-2, pp. 181–211

为了仍评价原任务的折扣回报，我们按一次 Option 的实际执行边界分组，而不按高层调用次数重新计时。设调用从 t 执行至 $t+K$，前 K 步奖励归入本次行为，余下回报从 $t+K$ 开始；逐项写出便有

$$\begin{aligned} G_t &= r_t + \gamma r_{t+1} + \cdots + \gamma^{K-1} r_{t+K-1} + \gamma^K (r_{t+K} + \gamma r_{t+K+1} + \cdots) \\ &= R_t^\omega + \gamma^K G_{t+K}, \qquad R_t^\omega := \sum_{j=0}^{K-1} \gamma^j r_{t+j}. \end{aligned} \tag{3.52}$$

这个等式对每次持续时间有限的 Option 调用成立，再按给定 $s_t = s, \omega_t = \omega$ 的分布取期望，就有

$$Q_\Omega^\zeta(s,\omega) = \mathbb{E}\left[R_t^\omega + \gamma^K \sum_{\omega'} \zeta(\omega' \mid s_{t+K}) Q_\Omega^\zeta(s_{t+K}, \omega') \,\middle|\, s, \omega \right]. \tag{3.53}$$

因此高层回放至少应保存 $(s_t, \omega, R_t^\omega, K, s_{t+K})$ 与环境终止标志。若终点是环境吸收终止，后继值为 0；Option 主动结束只是把控制权交回高层，后继值通常不为 0。

评价固定高层策略时按 ζ 平均下一 Option；改为控制时，则在下一状态允许启动的 $\Omega(s_{t+K})$ 中取最高估值，以改进后续高层选择。样本更新为

$$Q_\Omega(s_t,\omega) \leftarrow Q_\Omega(s_t,\omega) + \alpha \left[R_t^\omega + \gamma^K \max_{\omega' \in \Omega(s_{t+K})} Q_\Omega(s_{t+K},\omega') - Q_\Omega(s_t,\omega) \right].$$

把 γ^K 写成 γ 相当于用高层调用次数重新定义时间，会改变原始任务，而不是同一个目标下的近似实现。

定理 3.23 Option 备份的压缩性 设奖励有界，$0 \le \gamma < 1$，每个可用 Option 持续时间满足 $K \ge 1$ 且几乎处处有限。固定 Option 内部策略和终止规则。对有界终点价值 V, W，固定高层策略的备份与对可用 Option 取最大值的备份都满足 $\|\mathcal{T}_\Omega V - \mathcal{T}_\Omega W\|_\infty \le \gamma \|V - W\|_\infty$。

证明 固定 s, ω，累计奖励在两次备份相减时抵消，余项绝对值至多为

$$\mathbb{E}[\gamma^K |V(s_{t+K}) - W(s_{t+K})| \mid s, \omega] \le \mathbb{E}[\gamma^K \mid s, \omega] \|V - W\|_\infty \le \gamma \|V - W\|_\infty.$$

高层概率平均不增大此界；最大值满足 $|\max_\omega x_\omega - \max_\omega y_\omega| \le \max_\omega |x_\omega - y_\omega|$，故同样成立。对 s 取上确界即得结论。 ■

固定内部策略和终止规则后，备份误差只来自终点价值，因而实际持续时间越长，这一误差的折扣越强；压缩因子可以收紧为 $\sup_{s,\omega} \mathbb{E}[\gamma^K \mid s, \omega]$。这里取上确界是要覆盖每个可启动状态与 Option，并不说明获得长行为的训练样本更少。若 Option 可能永不终止，原始折扣回报仍可能有定义，但下一高层决策时刻不再总是有限；需要另行规定该事件上的回报与备份，不能直接使用上述陈述。

示例 3.24 持续时间不能忽略 在房间网格的 $(4, 2)$ 到 $(6, 2)$，Option A 走两步，Option B 先绕行再用四步到同一终点；期间不碰最终目标，奖励均为 -0.04。假设终点价值为 0.8，则

$$y_A = -0.04(1 + 0.9) + 0.9^2(0.8) = 0.572,$$

$$y_B = -0.04(1 + 0.9 + 0.9^2 + 0.9^3) + 0.9^4(0.8) = 0.38732.$$

若错误地都只折扣一次，目标变为 0.644 与 0.58244，两者都被高估。持续时间随机时应平均 $\gamma^K V(s_{t+K})$，一般不能换成 $\gamma^{\mathbb{E}K} \mathbb{E}V$。

3.6.3 分层价值与策略学习

Option 备份暂时固定了内部策略和终止规则，接下来要决定怎样获得它们。手工指定“到下门”时，低层读取当前格点和门位置，输出方向，并可用到门奖励训练；高层读取当前房间和外在任务，选择子目标，仍以原始折扣奖励评价。如果不预先指定门位置，Option-Critic 可以直接用外在回报训练内部策略及终止概率。图3.26区分各层输入、动作与奖励，避免把低层辅助目标混成全局任务。

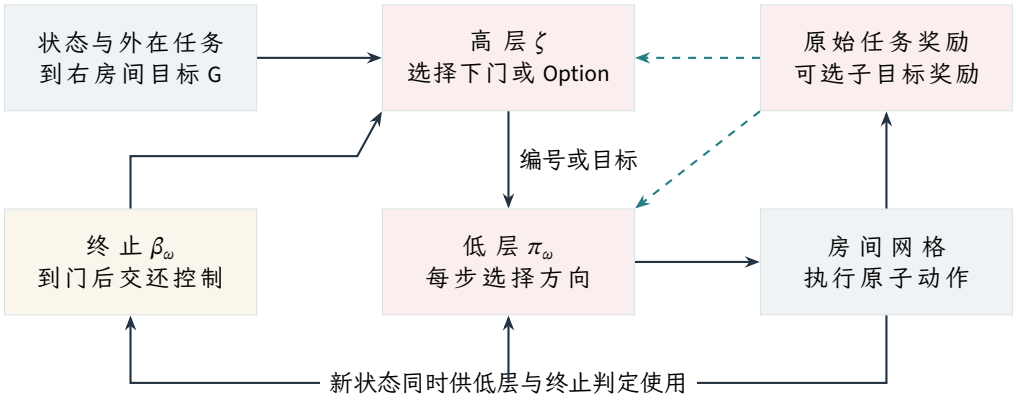


图 3.26 房间任务的分层接口。高层交付子目标或 Option 编号，低层持续输出原子动作，终止后才交回控制权。右侧区分原始任务奖励与可选的低层辅助奖励；Option-Critic 无需人为指定这一辅助奖励。

每个原子步之后既可能继续当前 Option，也可能终止并重选，所以评价还需保留当前 Option 编号。Option-Critic 为这两种后续选择分别估值。本小节假定所有 Option 在所有非终止状态均可启动，记 $Q_\Omega(s,\omega)$ 为当前继续执行 ω 的价值，$V_\Omega(s)=\sum_{\omega'}\zeta(\omega'\mid s)Q_\Omega(s,\omega')$ 为重新选择的价值。到达 s' 后，尚未作终止选择的价值是

$$\begin{aligned} U(\omega,s') &= (1-\beta_\omega(s'))Q_\Omega(s',\omega)+\beta_\omega(s')V_\Omega(s'),\\ Q_U(s,\omega,a) &= R(s,a)+\gamma\mathbb{E}_{s'\sim P(\cdot|s,a)}U(\omega,s'),\\ Q_\Omega(s,\omega) &= \sum_a \pi_\omega(a\mid s)Q_U(s,\omega,a). \end{aligned} \tag{3.54}$$

这些关系允许每个原子步更新评论家，而不必等 Option 结束。采样转移的目标是 $y=r_t+\gamma U(\omega_t,s_{t+1})$，环境终止时令 $U=0$；内部策略则提高 Q_U 大的动作的概率。

固定高层 ζ 及终止参数，用 θ 参数化内部策略。定义当前执行状态与 Option 的归一化占用 $d_\Omega(s,\omega)=(1-\gamma)\sum_{t\ge0}\gamma^t\mathbb{P}(s_t=s,\omega_t=\omega)$。环境终止后以零奖励吸收态和固定虚拟 Option 延拓，使占用总质量仍为 1；该延拓不贡献参数梯度。将普通策略梯度应用于包含 Option 的扩展过程，可得

$$\nabla_\theta J=\frac{1}{1-\gamma}\mathbb{E}_{(s,\omega)\sim d_\Omega,\ a\sim\pi_\omega}[\nabla_\theta\log\pi_\omega(a\mid s)Q_U(s,\omega,a)]. \tag{3.55}$$

基线 $Q_\Omega(s,\omega)$ 与动作无关，可以减去以形成内部优势。推导中的占用仍按原子时间折扣，而不是每切换一次 Option 才折扣。

终止规则的方向可直接从 U 看出。若 $\boldsymbol{\nu}$ 参数化 β，对终止概率的局部导数是 $V_\Omega(s')-Q_\Omega(s',\omega)=-A_\Omega(s',\omega)$。展开未来各次到达的影响，得到

$$\nabla_{\boldsymbol{\nu}} J=-\sum_{t\ge 0}\gamma^{t+1}\mathbb{E}[\nabla_{\boldsymbol{\nu}}\beta_{\omega_t}(s_{t+1})A_\Omega(s_{t+1},\omega_t)]. \tag{3.56}$$

前面的 γ 来自先走一步再决定终止。若将到达分布 $(1-\gamma)\sum_t \gamma^t \mathbb{P}(s_{t+1},\omega_t)$ 归一化，上式系数就是 $-\gamma/(1-\gamma)$。当前 Option 比重新选择更好时 $A_\Omega>0$，梯度会降低终止概率；较差时则提高。高层策略本身若也需求导，应另计高层选择时刻的贡献，不能藏进这个固定 ζ 的偏导。完整的策略与终止梯度关系见 Option-Critic 原论文[83]。

例如人工评价值为 $Q_\Omega(s',\omega)=0.6$、$V_\Omega(s')=0.9$，当前 $\beta=\sigma(\nu)=0.25$，则 $U=0.675$。前一步奖励 -0.04、$\gamma=0.9$ 时，评论家目标为 0.5675。终止 logit 的局部上升方向为 $-\beta(1-\beta)A_\Omega=0.05625$；把它乘对应到达折扣权重后，提高终止概率。这一方向不是“价值低就终止”，而是“继续比切换更差就终止”。

其他分层方法主要改变任务分解与数据复用方式，不能简单替换上述三个学习对象。Feudal RL 用管理者向下层发指令，由下层完成指令获取局部奖励；状态划分与层级接口提供了强先验，也限制了能表达的行为[84]。

MAXQ 把任务写成子任务图，将“执行子任务本身的价值”与“完成它以后还剩多少价值”分开。若在父任务 i 中选择子任务 a，完成后用 $C_i(s,a)$ 表示父任务剩余部分，则决策评价具有 $Q_i(s,a)=V_a(s)+C_i(s,a)$ 的结构，完成项包含子任务持续时间的折扣。它学习的是给定分解下的价值；递归最优只要求每个子任务在固定子层下最优，比原始 MDP 全局最优弱[85]。

HIRO 用高层给出的相对目标 $\boldsymbol{g}_t$ 训练低层。在固定执行窗口内，低层输入状态与目标，以到达 $\boldsymbol{s}_t+\boldsymbol{g}_t$ 的距离作为辅助信号，状态变化后相对目标相应平移。低层更新会使旧高层动作失去原意：过去“向东两格”的目标现在可能对应另一串原子动作。HIRO 从候选新目标中寻找使记录动作在当前低层策略下最可能的目标，即近似最大化 $\sum_i \log \pi_{\text{low}}(a_i \mid s_i,\tilde{\boldsymbol{g}}_i)$，再用它重标记高层经验。它校正的是低层行为变化，不是把未发生的真实轨迹补出来[86]。

HAC 则把实际达到的状态作为事后高层动作，并在各层做目标重标记，以近似“下层已经能完成这个动作”的训练接口；另外安排子目标测试，对当前低层不能完成的提议施加相应惩罚。只使用成功的事后重标记、忽略测试，会让上层把不可达子目标估得过高[87]。

表3.29所列先验可能降低学习难度，也可能排除好策略。在图3.25中，若所有高层策略都被强制先到 $(4,4)$，最短路线从五步变为九步。对应回报分别是 $-0.04\sum_{j=0}^{3}0.9^j+0.9^4=0.51854$ 和 $-0.04\sum_{j=0}^{7}0.9^j+0.9^8\approx 0.20265$。即使每个子任务都学得完美，仍无法恢复被层级排除的下门直达路线。若

[83] P.-L. Bacon, J. Harb, D. Precup, *The Option-Critic Architecture* In Proceedings of the AAAI Conference on Artificial Intelligence, 2017, pp. 1726–1734

[84] P. Dayan, G. E. Hinton, *Feudal Reinforcement Learning* In Advances in Neural Information Processing Systems, 1993, pp. 271–278

[85] T. G. Dietterich, *Hierarchical Reinforcement Learning with the MAXQ Value Function Decomposition* In Journal of Artificial Intelligence Research, 2000, vol. 13, pp. 227–303

[86] O. Nachum, S. Gu, H. Lee, S. Levine, *Data-Efficient Hierarchical Reinforcement Learning* In Advances in Neural Information Processing Systems, 2018

[87] A. Levy, G. Konidaris, R. Platt, K. Saenko, *Learning Multi-Level Hierarchies with Hindsight* In International Conference on Learning Representations, 2019

方法	预先给定的结构	学习对象与数据难点
Feudal RL	管理层级、状态抽象与指令接口	各层指令选择和执行策略；局部奖励可能限制全局行为
MAXQ	子任务图、终止条件及可能的伪奖励	子任务值与完成项；保证依赖任务分解和状态抽象条件
Option-Critic	Option 数量、参数化及启动约定	内部策略、终止与高层价值；可能退化为过短或重复 Option
HIRO	目标坐标、执行窗口、距离奖励	高低层离策略策略；用当前低层动作似然校正旧目标
HAC	各层目标空间、执行预算及测试机制	多层目标策略；事后动作、事后目标和子目标测试分工不同

表 3.29 分层方法的先验与学习边界。表中层级都需要明确的状态、目标、动作和奖励接口，不是把同一个单层算法重复堆叠即可。

同时保留全部原子动作且允许高层任意选择，它仍可表示原始最优策略，但搜索和学习未必会及时找到它。

3.6.4 技能发现与下游复用

手工指定门口已经利用了下游任务知识。没有外在奖励时，可以先训练一组产生不同可控后果的行为，随后检验它们能否被任务策略调用。**技能变量**Z 是一次调用前抽取的行为标识，策略 $\pi(a \mid s, z)$ 根据它选择动作；后果 Y 可取终点、访问状态或轨迹摘要。判别器 $q_\psi(z \mid y, s_0)$ 从后果反推技能。不同技能若总到同一处便难以区分；若差别仅来自不可控噪声，也难以由技能稳定产生。这里希望学习的是选择行为可以改变的后果。

定义 3.25 互信息与赋能的控制含义 在固定起点 s_0 与给定执行时域下，

$$I(Z; Y \mid s_0) = \mathbb{E} \log \frac{p(Z \mid Y, s_0)}{p(Z \mid s_0)} = \mathcal{H}(Y \mid s_0) - \mathcal{H}(Y \mid Z, s_0).$$

它衡量选择技能能让后果携带多少可辨识信息。赋能（empowerment）将这种“对后果有多少可区分的控制选择”写成信道容量，例如对原子动作序列的分布取 $\max_{p(a_{0:K-1} \mid s_0)} I(A_{0:K-1}; S_K \mid s_0)$。用可学习闭环技能替代开环动作序列会改变允许的控制类，应明确所用版本。

计算互信息需要技能与后果的联合分布，但真实后验 $p(z \mid y, s_0)$ 通常不能直接计算。判别器给出一个可由带技能标签的经验拟合的替代概率；用它构造下界，策略就有可计算的训练信号。向定义中加减 $\log q_\psi$，有

$$\begin{aligned} I(Z; Y \mid s_0) &= \mathbb{E}\left[\log q_\psi(Z \mid Y, s_0) - \log p(Z \mid s_0)\right] \\ &\quad + \mathbb{E}_Y D_{\mathrm{KL}}(p(\cdot \mid Y, s_0) \| q_\psi(\cdot \mid Y, s_0)) \\ &\geq \mathbb{E}\left[\log q_\psi(Z \mid Y, s_0) - \log p(Z \mid s_0)\right]. \end{aligned} \tag{3.57}$$

判别器用带已知技能标签的经验做最大似然训练；策略把括号内的量当作内部奖励。这一推导只用 KL 非负性，但所得到的学习质量仍取决于后果选择、判别器容量、采样覆盖与优化。固定均匀先验时 $-\log p(z)$ 是常数，不代表每个技能已经覆盖到有用区域。

VIC 以给定初始状态后的终止状态区分 Option，正适合上述条件互信息。终点奖励可经策略梯度分配给整段内部动作，终止规则也是技能含义的一部分[88]。

DIAYN 用访问到的状态区分技能，并加入动作熵来鼓励每个技能内的随机性。其常见内部奖励为 $\log q_\psi(z \mid s) - \log p(z)$，再由最大熵强化学习优化。它不是 VIC 的同一个条件终点目标：是否给判别器起点、对哪些时刻的状态取平均，都改变要区分的对象[89]。

DADS 希望技能的动力学后果既可预测又不同，目标围绕 $I(Z; S' \mid S)$。技能条件动力学 $q_\psi(s' \mid s, z)$ 给出形如

$$r^{\mathrm{int}} = \log q_\psi(s' \mid s, z) - \log \left[\frac{1}{M} \sum_{m=1}^{M} q_\psi(s' \mid s, z_m) \right], \qquad z_m \sim p(z)$$

的近似训练信号：给定技能要能预测后继，不给技能时却有多种可能。有限 M、学到的动力学和数据相关的技能分布都会影响估计，不能把这个有限样本比值一概当成精确互信息。学到的技能动力学还能支持下游在技能空间规划[90]。

[88] K. Gregor, D. J. Rezende, D. Wierstra, *Variational Intrinsic Control* In International Conference on Learning Representations, 2017

[89] B. Eysenbach, A. Gupta, J. Ibarz, S. Levine, *Diversity Is All You Need: Learning Skills without a Reward Function* In International Conference on Learning Representations, 2019

[90] A. Sharma, S. Gu, S. Levine, V. Kumar, K. Hausman, *Dynamics-Aware Unsupervised Discovery of Skills* In International Conference on Learning Representations, 2020

方法	主要区分对象	学习信号和容易遗漏的条件
VIC	给定起点后的技能与终点	条件判别式下界；终止与可达性决定后果空间
DIAYN	技能与技能下访问的状态	状态判别奖励加动作熵；可区分状态未必是任务相关状态
DADS	给定状态后的技能与后继	技能动力学的似然比；预测性和后继多样性同时重要
CIC	连续技能与状态转移表示	对比表示学习与表示熵奖励；嵌入距离及负样本设计影响结果

表 3.30 技能发现并不共享一个通用互信息损失。改变后果变量或条件变量，就改变了“行为不同”的含义。

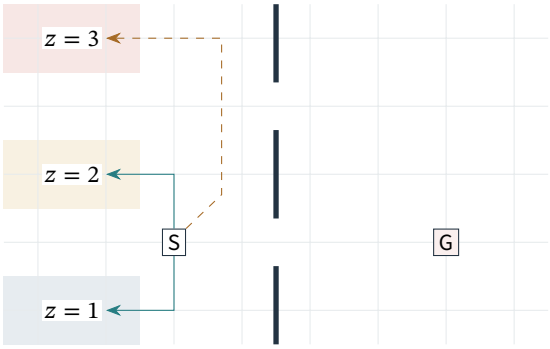


图 3.27 多样但不能完成跨房间任务的技能集合。三种填充和文字标识表示三组不同终点，所有内部策略都限制在墙左侧。可区分性并未提供穿门技能，也未保证一个技能的终点落入另一个有用技能的启动集。

CIC 则用状态转移与连续技能的对比学习构造行为表示，并在该表示中估计熵来提供探索奖励[91]。以转移嵌入 $\boldsymbol{v}_i$ 与技能嵌入 $\boldsymbol{u}_i$ 为例，批内匹配损失具有 $-\log[\exp(\mathrm{sim}(\boldsymbol{v}_i,\boldsymbol{u}_i)/\tau)/\sum_j \exp(\mathrm{sim}(\boldsymbol{v}_i,\boldsymbol{u}_j)/\tau)]$ 的形式。实际内在奖励还使用表示空间近邻距离的粒子熵估计，不能把这一对比损失直接等同于 DIAYN 的状态分类奖励。比较这类方法时，应分别检查表示训练与策略奖励的实现。

表3.30中的多样性都不能单独证明任务可解。图3.27给出一个反例：三个技能分别到左房间内三个不同区域，终点可完全区分，故均匀技能的终点互信息可达到 $\log 3$；但所有技能都不会穿门，任意高层组合也到不了右房间目标。这里为说明达到互信息上限，技能内部均确定，且每次调用都只在左房间活动；访问区域是人工定义，不是实测热图。

即使已经有穿门技能，组合还需要启动集相容、终点分布合适和终止时机可靠。评价复用不能只看无奖励阶段的互信息或覆盖面积，还要计入下游技能选择、微调和新增交互成本。这些跨任务问题在第6章继续展开；本章保留的结论是：时间抽象能改变搜索和学习的单位，但没有取消覆盖、估计与优化三方面的条件。

[91] M. Laskin, H. Liu, X. B. Peng, D. Yarats, A. Rajeswaran, P. Abbeel, *Unsupervised Reinforcement Learning with Contrastive Intrinsic Control* In Advances in Neural Information Processing Systems, 2022, pp. 34478–34491

保证对象	数学陈述或测量量	必须说明的输出条件
PAC 输出	概率至少 $1-\delta$ 时次优度不超过 ϵ	固定预算或停止规则；参照类；单策略还是混合策略
累积遗憾	$\mathrm{Reg}_K \le B(K,\delta)$，或其期望界	交互过程中全部回合；高概率与期望界不可互换
Simple regret	输出次优度 $\Delta_N = J^* - J(\hat{\pi}_N)$	可报告 $\mathbb{E}\Delta_N$ 或高概率界，须区分二者
策略识别	$\mathbb{P}(\hat{\pi} \in \Pi^*) \ge 1-\delta$	精确识别通常依赖正间隙；等价最优策略可能不唯一
最后迭代	对 $\pi^{(K)}$ 本身保证次优度	平均遗憾小不排除最后一轮很差，不能用混合输出替代

表 3.31 有限数据保证的对象。渐近收敛、PAC 输出、学习过程遗憾与最后迭代性质回答不同问题。

3.7 样本复杂度与可学习边界

前面给出了经验如何进入更新，也列出了渐近收敛条件。有限预算还需要回答另一个问题：在声明的环境族中，多少真实反馈足以保证输出策略近优，或控制学习期间的回报损失？本节固定访问协议、问题族和函数类分析这一信息需求。重复梯度与模型生成经验只重复利用已有证据，不能增加这些保证所计数的真实样本。

3.7.1 保证对象与数据访问模型

若目标是在训练后得到可部署策略，就应控制输出的次优度，而非仅控制某次训练误差。设算法用 N 次环境反馈输出 $\hat{\pi}_N$，参照 π^* 是在声明策略类中最大化 J 的策略。给定可接受损失 ϵ 与失败概率 δ，折扣 PAC 目标要求训练随机性以至少 $1-\delta$ 的概率产生损失不超过 ϵ 的输出：

$$\mathbb{P}\{J(\pi^*) - J(\hat{\pi}_N) \le \epsilon\} \ge 1-\delta. \tag{3.58}$$

概率覆盖训练数据及算法随机性；J 本身已经对部署环境取期望。若限制参照为某函数类诱导的策略，就只能称为该类内的近似最优，不应写成全局最优。允许输出一个在回合开始随机选择成员的策略混合时，还应明确这个随机化接口，而不是默认为单个最后网络。

有限时域设有 K 回合，每回合 H 步，$T = KH$。记算法第 k 回合使用策略 $\pi^{(k)}$，其起点为 $s_0^{(k)}$，常见累积伪遗憾为

$$\mathrm{Reg}_K = \sum_{k=1}^{K} \left[V_0^*(s_0^{(k)}) - V_0^{\pi^{(k)}}(s_0^{(k)}) \right]. \tag{3.59}$$

每项是给定本回合决策规则后的期望价值差，不是最优期望减去某条实际轨迹的偶然回报。前者关注整个学习过程付出的代价；式(3.58)只关注最终输出。表3.31把容易混淆的量分开。

访问协议	允许的查询	样本保证必须承担的困难
生成模型	指定任意状态动作，抽真实独立转移	仍要估计小差异，但免去实际到达目标状态的代价
在线回合	每回合从约定分布或对手给定起点开始	必须通过动作取得覆盖，回合内不能任意跳到未见状态
单条持续轨迹	不任意重置，后续状态承接前一动作	可达性、返回时间和陷阱；平均奖励常需通信性等条件
低适应轮数	每轮批量采样规则先确定，轮间才能按新数据调整	即使总样本相同，反馈轮数有限也可能增加探索成本

表 3.32 样本数只有放在访问协议中才有意义。低适应轮数是对查询反馈节奏的附加约束，可以叠加到回合或生成模型协议上。

例如在固定初始分布下，若平均伪遗憾不超过 ϵ，均匀抽取一个已执行策略作为输出，其条件期望次优度不超过 ϵ；这还不是概率 $1-\delta$ 的 PAC 结论。要得到高概率选择，可增加独立评价与置信控制，或使用专门的在线到批量转换。平均策略参数也不等于随机选择策略的混合，神经网络尤其如此。

同一个输出保证，在不同访问能力下可能需要不同样本数。理论中的**生成模型**（generative model）是查询预言机：可指定任意合法 (s,a)，得到独立的真实后继和奖励样本；它不是从有限数据训练出的预测模型。基准网格中，这个预言机可直接采样 $(4,2)$ 向上的后果，在线智能体却必须从 $(1,1)$ 先到达那里，还可能滑移。表3.32区分查询和实际到达的代价。

“样本高效”至少应补成一条可检验的任务说明。例如，折扣版本可以是：有限 $S=|\mathcal{S}|, A=|\mathcal{A}|$、奖励在 $[0,1]$、$\gamma=0.9$、有生成模型，以概率 0.95 输出满足 $J^*-J\le 0.1$ 的策略，并报告总查询数。有限时域版本应改为 $H=20$、$V_H=0$、在线回合采样，以及有限时域价值差；它的回报上界为 20，而不是 $1/(1-\gamma)=10$。平均奖励版本则需给出持续轨迹、通信 MDP 及例如直径 D 的条件，以长期增益 g^π 或 $Tg^*-\sum_{t<T} r_t$ 为目标，不能沿用折扣 J。

这些数字只是协议填写示例，不是某算法已达到的实验结果。后文为比较理论将分别声明奖励范围；这也不改变基准网格原有的负步成本。若论文用 K 表示回合数而另一篇用 T 表示时间步，须先代入 $T=KH$。同样，按每步奖励不超过 1 和按整回合总奖励不超过 1 推导的界，会有不同的时域依赖。

3.7.2 表格 MDP 的样本复杂度与遗憾

有限状态动作可以逐对计数，因此探索能直接利用各处尚余的统计不确定性。未充分访问的动作暂留较高估值；真实访问更新经验奖励、转移和置信半径，证据增多后高估值逐渐降低。要让这项不确定性产生远处探索行

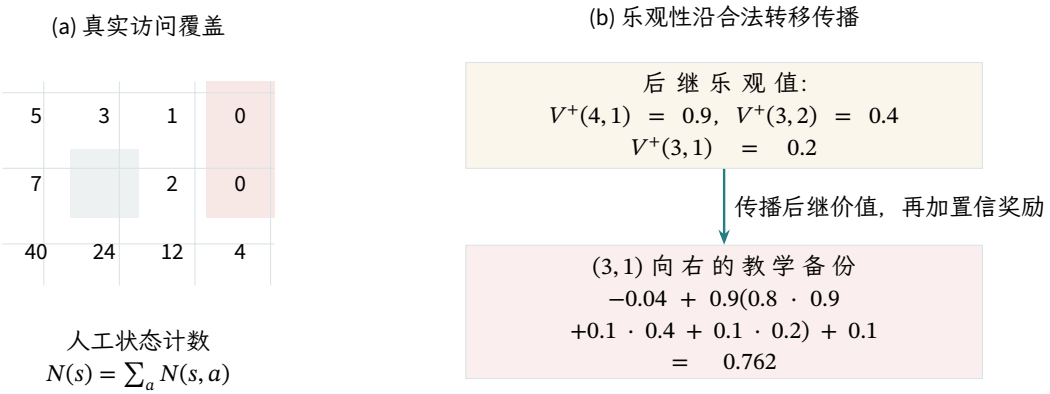


图 3.28 计数通过乐观备份影响上游决策。左侧是基准网格合法状态上的人工访问次数，不是实验热图；右侧用一条合法的向右转移说明未知后继的高估值如何影响当前动作。图中折扣教学备份不是下面有限时域 UCBVI 定理的数值实验。

方法	保证目标及访问方式	乐观机制与必要条件
E^3	有限 MDP 的 PAC 型学习，原分析包含有效时域与混合条件	已知区域评价与到达未知区域的探索规划分开
R-MAX	有限 MDP 近最优学习；平均奖励表述依赖适当混合时间参数	不足计数的状态动作给予最大回报的乐观模型
UCRL2	无重置的持续任务遗憾	有限直径的通信 MDP，奖励和转移置信集合上规划
UCBVI	固定长度在线回合的遗憾	经验转移与价值置信奖励；下述结果使用时齐转移

表 3.33 表格探索保证的任务条件。PAC 与遗憾不能只按一个样本数排列，持续任务与回合任务也不具有相同访问能力。

为，还需通过 Bellman 备份传回当前可选动作。图3.28将计数与乐观备份并列，说明采样和决策怎样相接。

E^3 区分在已知区域利用与主动走向未知区域的策略；R-MAX 把不够了解的状态动作暂时接到乐观的高奖励模型[92]。两者的重要思想是：无法证明当前策略已经足够好时，就要能以足够概率获得新信息。其原始 PAC 型结果需要声明有限规模、奖励界，以及所用有效时域或混合条件，不能从“模型乐观”直接推出任意持续任务的保证。

回合重置并非每个任务都可用。UCRL2 转向持续平均奖励 MDP，并要求通信性，即每个状态都能由某种策略到达其他状态。为量化到达代价，定义 $D = \max_{s,s'} \min_\pi \mathbb{E}_s^\pi \tau_{s'}$ 为直径，其中 $\tau_{s'}$ 是到达 s' 的时间。有限 D 排除了某些不可逆陷阱。它在奖励与转移置信集合中选择乐观模型，并按访问计数增长重新规划；在奖励 $[0,1]$、未知有限 S, A 的设定下，原论文给出高概率 $\widetilde{O}(DS\sqrt{AT})$ 遗憾界。这个 D 不能用回合长度 H 不加说明地替换[93]。

[92] R. I. Brafman, M. Tennenholtz, *R-MAX: A General Polynomial Time Algorithm for Near-Optimal Reinforcement Learning* In Journal of Machine Learning Research, 2002, vol. 3, pp. 213–231

[93] T. Jaksch, R. Ortner, P. Auer, *Near-Optimal Regret Bounds for Reinforcement Learning* In Journal of Machine Learning Research, 2010, vol. 11, no. 51, pp. 1563–1600

表3.33中的 UCBVI 直接在经验 Bellman 备份上加置信奖励。为展示一个具有明确时域依赖的结果，以下固定原论文的设定：S 个状态、每状态 A 个动作、已知确定性奖励 $R(s,a)\in[0,1]$、未知时齐转移 P，每回合 H 步，$V_H=0$，没有任意状态查询；回合起点可以由环境选定。第 k 回合前的总访问数为 $N^{(k)}(s,a)$，经验转移为 $\widehat{P}^{(k)}$。因为真实 P 不随回合内时刻改变，转移样本可跨时刻合并；若每个时刻有独立 P_t，统计维数与界会改变。

这一有限时域目标没有折扣，后继价值按剩余步数直接加入。反向计算时，先以经验转移平均后继值，再加置信奖励得到上界；取合法动作的最大值来选择较高回报。还用全程上限 H 和历史上界限制估值，典型更新为

$$Q_t^{(k)}(s,a)=\min\left\{Q_t^{(k-1)}(s,a),\,H,\,R(s,a)+\widehat{P}^{(k)}V_{t+1}^{(k)}(s,a)+b_t^{(k)}(s,a)\right\},$$

$V_t^{(k)}=\max_a Q_t^{(k)}$；未访问项保持乐观上限。简单 Hoeffding 半径取 $H\sqrt{L/N}$ 量级能说明机制，但不能冒领 Bernstein–Freedman（BF）版本的较好界。BF 使用后继价值的经验方差,并对随机估值引入额外校正。记 $N=N^{(k)}(s,a)>0$、$\widehat{P}=\widehat{P}^{(k)}(\cdot\mid s,a)$，$n_{t+1}^{(k)}(y)$ 为先前回合在相应时刻访问状态 y 的次数，写出其三个部分：

$$b_t^{(k)}(s,a)=\sqrt{\frac{8L\,\mathrm{Var}_{\widehat{P}}(V_{t+1}^{(k)})}{N}}+\frac{14HL}{3N}+\sqrt{\frac{8}{N}\sum_y\widehat{P}(y)\min\left\{\frac{100^2H^3S^2AL^2}{n_{t+1}^{(k)}(y)\vee 1},H^2\right\}}.\tag{3.60}$$

第一项按经验后继价值方差设平方根半径，第二项是有限样本范围修正，第三项补偿估值本身由数据拟合造成的误差；其中求和按经验后继分布平均，各状态的修正取计数界与 H^2 中较小者。零次计数仍以乐观上限处理，末端已知零价值无需估计。若省去第三项，就不能把数据依赖的 $V_{t+1}^{(k)}$ 方差直接当成固定真实价值的方差来使用原保证。

定理 3.26　UCBVI-BF 的一个有限时域遗憾界　在上述有限、已知奖励、时齐转移的在线回合设定下，令 $T=KH$、$\delta\in(0,1)$、$L=\log(5HSAT/\delta)$。采用 UCBVI-BF 原算法及相应置信奖励，以至少 $1-\delta$ 的概率，

$$\mathrm{Reg}_K\le 30L\sqrt{HSAT}+2500H^2S^2AL^2+4H\sqrt{TL}.\tag{3.61}$$

这里的遗憾为式(3.59)的回合价值差之和。次要项没有被并入主项；只有在相应大样本区域，才适合用 $\widetilde{O}(\sqrt{HSAT})$ 概括其主导尺度。

该结果来自 Azar、Osband 与 Munos 的定理 2；其以回合数表示的首项为 $30HL\sqrt{SAK}$，末项为 $4H^{3/2}\sqrt{KL}$，代入 $T = KH$ 后得到上式。下面解释证明的四个支点，不将简化推导替代原论文对常数和次要项的完整处理[94]。

[94] M. G. Azar, I. Osband, R. Munos, *Minimax Regret Bounds for Reinforcement Learning* In Proceedings of the 34th International Conference on Machine Learning, 2017, pp. 263–272

置信事件支持反向乐观性 加上置信奖励的价值备份首先要成为真实价值的上界，才能指导探索。因此需在奖励已知的设定下，对全部回合、时刻和状态动作同时建立转移集中事件，而不仅保证当前所选动作。由 $V_H = 0$ 反向归纳，控制 $(\widehat{P}-P)V^*_{t+1}$ 以及数据依赖估值带来的额外项，证明 $V^{(k)}_t \geq V^*_t$。对动作取最大保留上界；在多个历史上界中取最小也保留上界，因为它们在同一事件上均不低于真实值。只控制当前访问点，或只控制一个预先固定价值函数，均不足以完成数据依赖估值的整段归纳。

把回合损失分成奖励与鞅差 乐观性使 $V^{(k)}_0 - V^{\pi^{(k)}}_0$ 足以覆盖本回合真实遗憾。沿实际访问轨迹展开 Bellman 关系，后继价值差的条件平均与本次实现之间留下零条件均值的随机项，这就是鞅差；其余由置信奖励和误差修正控制。相邻价值项逐步抵消后，只需累加实际访问处的这些量，不必每回合对全部 SA 项重复付出误差。因此，下一步可以利用各处访问次数，而非仅按总时长给粗界。

用访问数而非时间粗界 对同一状态动作反复访问，平方根半径大致按本地次数 $n^{-1/2}$ 下降。将这一串递减半径求和，再合并全部状态动作的访问预算，关键关系为

$$\sum_{n=1}^{m} \frac{1}{\sqrt{n}} \leq 2\sqrt{m}, \qquad \sum_{n=1}^{m} \frac{1}{n} \leq 1 + \log m, \qquad \sum_{s,a} \sqrt{N_T(s,a)} \leq \sqrt{SAT}.$$

前两个界分别控制平方根半径和逆计数修正；最后一步用 Cauchy–Schwarz 及 $\sum_{s,a} N_T(s,a) = T$ 将各处次数合并。这也说明半径缩小所依据的是新的真实访问，不能用重复训练次数代替没有增加的观测数。

用方差避免多付一个时域因子 计数求和仍需知道每个半径的尺度。若每步都仅用后继价值范围 H 给界，就忽略了整回合随机性的共同限制，累计时会多付时域因子。BF 分析利用沿轨迹的条件方差总和与总回报方差的关系，并用 Freedman 不等式控制鞅项；随机估值另由式(3.60)末项校正。将方差累计与访问计数结合，得到 $\sqrt{HSAT}$ 主项，罕见状态和估值修正仍保留为显式次要项。

在相同在线、有限、时齐模型的适当非退化参数及足够大 T 范围内，存在问题族使最坏情形期望遗憾至少为 $c\sqrt{HSAT}$ 量级，$c > 0$ 为通用常数；因此上述主项对 S, A, H, T 的依赖有相应辨识困难支撑。这是期望下界与高概率上界的尺度比较，不是把两者概率陈述视为相同。若允许每个时刻

独立变化的转移核，或者用整回合奖励归一化，必须重新比较，不应引用同一式子。第3.7.5节再用可完整计算的问题对解释下界如何产生。

3.7.3 结构化函数逼近的样本效率

图像或连续状态中几乎每次观测都不同，逐状态计数无法等到每处充分访问。跨状态共享样本需要可检验的结构，而不是仅给未知输入较小网络误差。线性价值近似只规定预测形式；线性 MDP 进一步要求奖励与转移共同由已知特征线性表示，使各种后继价值的备份也留在同一特征空间。下面区分这种结构与线性混合模型，避免把名称中的“线性”当成相同保证。

定义 3.27　线性 MDP 与线性混合 MDP　在有限时域 $t = 0, \dots, H-1$ 中，若已知特征 $\boldsymbol{\phi}(s,a) \in \mathbb{R}^d$，存在未知参数 θ_t 和向量测度 $\boldsymbol{\mu}_t$ 使

$$R_t(s,a) = \boldsymbol{\phi}(s,a)^\top \theta_t, \qquad P_t(B \mid s,a) = \boldsymbol{\phi}(s,a)^\top \boldsymbol{\mu}_t(B)$$

对所有可测集合 B 成立，则称为相应特征下的线性 MDP。表示右侧必须非负且对全空间等于 1。线性混合 MDP 的一种常用形式则是已知基核 $P_{t,i}$、未知混合权重 $\eta_{t,i}$：

$$P_t(\cdot \mid s,a) = \sum_{i=1}^{d} \eta_{t,i} P_{t,i}(\cdot \mid s,a), \qquad \boldsymbol{\eta}_t \in \Delta_d.$$

更一般的线性混合允许其他系数约束，但仍必须保证最终概率核合法。

第一种结构把状态动作依赖放在已知特征中，未知的是后继状态上的测度；第二种把每个候选后果分布预先给出，未知的是共享系数。在线性混合下，对给定 V 可计算特征 $(P_{t,1}V(s,a), \dots, P_{t,d}V(s,a))$，它随 V 改变。在线性 MDP 下，原特征 $\boldsymbol{\phi}(s,a)$ 不随目标改变。二者都称“线性”，并不表示证明条件可以互换。

线性 MDP 支持价值泛化的原因可直接推导。对任何有界后继价值 V，

$$R_t(s,a) + P_t V(s,a) = \boldsymbol{\phi}(s,a)^\top \left(\theta_t + \int V(s') \, \mathrm{d}\boldsymbol{\mu}_t(s') \right). \tag{3.62}$$

因此每次 Bellman 备份都仍是相同特征的线性组合。仅有 Q^* 线性可表示，则只约束一个最终解，不能推出任意中间 V 都满足式(3.62)。

这一闭合关系允许用真实转移回归价值参数，而无需枚举后继状态。LSVI-UCB 在每回合开始反向重算旧样本的后继目标，做正则化最小二乘，

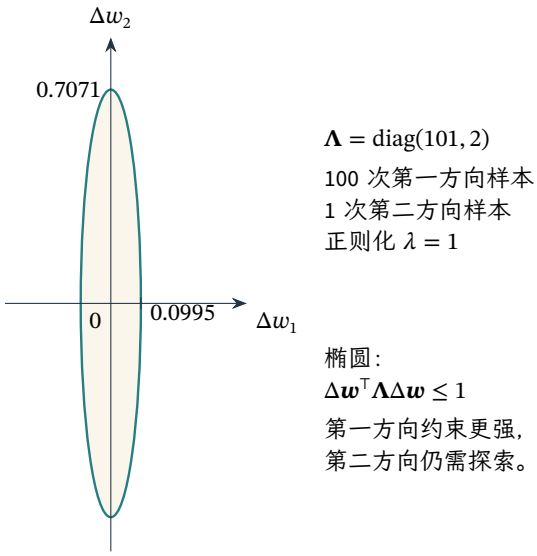


图 3.29　经验设计矩阵约束的是特征方向。人工例子中 $\mathbf{\Lambda} = \mathrm{diag}(101, 2)$，参数误差椭圆在第一方向很窄、第二方向较宽。即使某个新状态从未出现，只要其特征方向已有充分数据，置信半径也可能较小。

再按未充分约束的特征方向加置信奖励。对第 k 回合，定义先前同一时刻的特征 $\boldsymbol{\phi}_t^{(i)} = \boldsymbol{\phi}(s_t^{(i)}, a_t^{(i)})$，令 $Q_H^{(k)} = 0$，由 $t = H-1$ 向 0 计算

$$
\begin{aligned}
\mathbf{\Lambda}_t^{(k)} &= \lambda \boldsymbol{I} + \sum_{i<k} \boldsymbol{\phi}_t^{(i)} \boldsymbol{\phi}_t^{(i)\top}, \\
\boldsymbol{w}_t^{(k)} &= (\mathbf{\Lambda}_t^{(k)})^{-1} \sum_{i<k} \boldsymbol{\phi}_t^{(i)} \left[r_t^{(i)} + \max_a Q_{t+1}^{(k)}(s_{t+1}^{(i)}, a) \right], \\
b_t^{(k)}(s,a) &= \beta \sqrt{\boldsymbol{\phi}(s,a)^{\top} (\mathbf{\Lambda}_t^{(k)})^{-1} \boldsymbol{\phi}(s,a)}, \\
Q_t^{(k)}(s,a) &= \min\{H, \boldsymbol{\phi}(s,a)^{\top} \boldsymbol{w}_t^{(k)} + b_t^{(k)}(s,a)\}.
\end{aligned}
\tag{3.63}
$$

之后执行 $a_t^{(k)} \in \arg\max_a Q_t^{(k)}(s_t^{(k)}, a)$ 收集一整回合，将真实记录加入下一轮拟合。上式使用原算法的全程上限 H；当前回合的后继估值会重新生成旧样本的回归目标，不能把它误解成只更新最新一个样本的固定标签回归。

图3.29中的矩阵来自 $\lambda = 1$、100 个 $\boldsymbol{e}_1$ 样本和一个 $\boldsymbol{e}_2$ 样本。去掉共同系数 β 后，两方向的置信半径分别为 $1/\sqrt{101} \approx 0.0995$ 和 $1/\sqrt{2} \approx 0.7071$。半径关心数据是否约束了该方向，而不是网络对输入是否“熟悉”。已知特征若没有上述模型实现性，椭圆再窄也可能自信地逼近一个错误模型。

定理 3.28 线性 MDP 中 LSVI-UCB 的代表性保证 考虑可观测状态、有限动作、H 步在线回合，$T = KH$，初始状态允许由环境选择，奖励为确定性 $R_t(s,a) \in [0,1]$。真实 MDP 满足定义3.27的线性 MDP 表示，已知 $\|\boldsymbol{\phi}(s,a)\|_2 \le 1$、$\|\theta_t\|_2 \le \sqrt{d}$；为明确测度有界性，取充分条件

$$\left\| \int v(s') \, \mathrm{d}\boldsymbol{\mu}_t(s') \right\|_2 \le \sqrt{d}\, \|v\|_\infty \quad \text{对所有有界可测} v.$$

采用 $\lambda = 1$ 与充分大的通用常数 c，令 $\beta = c\, dH\sqrt{\log(2dT/\delta)}$。LSVI-UCB 以至少 $1-\delta$ 的概率满足

$$\mathrm{Reg}_K \le C\sqrt{d^3H^3T}\log(2dT/\delta) = \widetilde{O}(\sqrt{d^3H^3T}),$$

其中 C 为通用常数。它不需要生成模型访问，也没有显式状态数依赖；动作最大化和特征计算仍必须可执行。

这是 Jin 等人的线性 MDP 结果；上面将测度规范写成对所有有界测试函数的充分有界条件，避免把有符号测度的总质量与总变差混淆。论文对奖励随机性及模型失配另有讨论，此处不把那些扩展条件省略后并入定理[95]。

[95] C. Jin, Z. Yang, Z. Wang, M. I. Jordan, *Provably Efficient Reinforcement Learning with Linear Function Approximation* In Proceedings of Thirty Third Conference on Learning Theory, 2020, pp. 2137–2143

证明沿两条线推进。统计上，式(3.62)使真实备份存在一个范数受控的线性参数；正则化最小二乘的误差可由 $\|\boldsymbol{\phi}\|_{\boldsymbol{\Lambda}^{-1}}$ 界住。数据是自适应采集的，后继估值又用到整批数据，因此既要用自归一化鞅集中，也要对算法可能生成的价值类作统一控制，不能把普通独立回归置信区间直接照搬。

决策上，反向归纳得到乐观性，再把遗憾分解为访问轨迹上的置信奖励与鞅项。矩阵行列式引理给

$$\det(\boldsymbol{\Lambda} + \boldsymbol{\phi}\boldsymbol{\phi}^{\top}) = \det(\boldsymbol{\Lambda})(1 + \|\boldsymbol{\phi}\|^2_{\boldsymbol{\Lambda}^{-1}}),$$

所以有限时刻内所有新方向的不确定性总和受 $\log\det\boldsymbol{\Lambda}$ 控制。结合 $\det\boldsymbol{\Lambda} \le (1 + K/d)^d$ 量级的上界、Cauchy–Schwarz 及 H 个时刻的求和，得到累计遗憾界。这是表格访问计数在共享特征空间中的对应物。

该保证约束了整个奖励与转移结构，而不仅是最优值的拟合误差。若任意神经网络在训练数据上能拟合 Q^*，不能据此认定它具有已知特征、Bellman 封闭性、可校准置信半径或高效动作最大化。表示学习可以帮助发现结构，但“能够训练”与“已满足该结构定理”仍是不同判断。

3.7.4 一般函数类的可学习条件

线性 MDP 的转移结构让中间备份仍可用同一特征表示。一般函数类未必如此：它可能包含最终正确答案，却不能拟合某个候选产生的下一次目标。

因此需要分开约束正确答案的可实现性和中间备份的 Bellman 完备性，而不能只用训练容量回答两者。

定义 3.29　可实现性与 Bellman 完备性　设有限时域动作价值类为 $\mathcal{F}=\mathcal{F}_0\times\cdots\times\mathcal{F}_{H-1}$，$\mathcal{F}_H=\{0\}$。可实现性要求 $Q_t^\ast\in\mathcal{F}_t$。Bellman 完备性要求对任意 $f_{t+1}\in\mathcal{F}_{t+1}$，

$$(\mathcal{T}_t f_{t+1})(s,a):=R_t(s,a)+\mathbb{E}_{s'}\max_{a'} f_{t+1}(s',a')\in\mathcal{F}_t.$$

若使用另一个回归类 $\mathcal{G}_t$ 容纳备份，则应写成 $\mathcal{T}_t\mathcal{F}_{t+1}\subseteq\mathcal{G}_t$，不应省略两个类的区别。

考虑两步、每步一个状态且只有一个动作、奖励全为 0 的教学任务。取 $\mathcal{F}_1=\{0,1\}$、$\mathcal{F}_0=\{0,2\}$，这里集合元素表示常数函数。真实最优值 $(Q_0^\ast,Q_1^\ast)=(0,0)$ 在类里；但把候选 $f_1=1$ 备份到前一步得到 $\mathcal{T}_0 f_1=1\notin\mathcal{F}_0$。因此可实现不保证每次回归目标可表示。反过来，在该有限时域、固定零终值与相同最优备份算子的完整闭合条件下，可从终点反向推出可实现性；这依赖这些匹配条件，而不是两个术语永远同义。

可实现性和完备性仍不直接限制辨识所需样本。庞大候选类若每次观测只排除一个独立候选，就可能需要大量试验；若候选错误共享有限个方向，同一访问分布上的检验可同时约束许多候选。Bellman rank 度量探索分布与候选平均 Bellman 误差之间能否由有限维内积表示，下面正式写出这种分解。

定义 3.30　一种 Bellman 因子分解　对候选价值函数 f,g，令 π_f,π_g 为各自贪心策略。先按 π_g 行动到时刻 t，再在 $t,t+1$ 按 π_f 行动，定义平均 Bellman 误差

$$\mathcal{E}_t(f,g)=\mathbb{E}[f_t(s_t,a_t)-r_t-f_{t+1}(s_{t+1},a_{t+1})].$$

若对每个 t 都存在 M 维映射 $\boldsymbol{\nu}_t(g)$、$\boldsymbol{\xi}_t(f)$ 使

$$\mathcal{E}_t(f,g)=\boldsymbol{\nu}_t(g)^{\top}\boldsymbol{\xi}_t(f),\qquad \|\boldsymbol{\nu}_t(g)\|_2\|\boldsymbol{\xi}_t(f)\|_2\le\zeta,$$

则该问题与函数类具有维度至多 M、范数参数 ζ 的 Bellman 因子分解。它同时依赖环境、函数类和访问分布，不只是某个网络权重矩阵的秩。

白话地说，$\boldsymbol{\nu}_t$ 描述“这次探索把我们带到了哪里”，$\boldsymbol{\xi}_t$ 描述“这个候选在那里会错多少”，二者通过有限维内积相遇。表格 MDP 可把状态概率与

逐状态误差作为两向量；结构更强时，所需维数可以小于状态数。这种分解不要求算法知道两映射，但证明靠它限制需要多少次有用的排除。

定理 3.31 低 Bellman rank 下的有限类 PAC 结果 考虑 H 步在线回合，可从固定初始分布重新开始，动作数为有限 A，每步奖励非负且整回合奖励和几乎处处不超过 1。给定有限价值类 $\mathcal{F}$，$|\mathcal{F}| = N$，函数值在 $[0,1]$，终值为 0，且真实 Q^* 可实现。假设该类与环境满足定义3.30的分解，并将范数上界取为 $\zeta \geq 1$；原上界不足 1 时可上调为 1，不改变分解条件。对任意 $\epsilon, \delta \in (0,1)$，OLIVE 采用原论文阈值与批量样本数，可在

$$\widetilde{O}\left(\frac{M^2 H^3 A}{\epsilon^2} \log \frac{N\zeta}{\delta}\right)$$

个回合内，以至少 $1-\delta$ 的概率输出次优度不超过 ϵ 的贪心策略。波浪号还隐藏 $M, H, A, 1/\epsilon$ 的对数项；若按原子环境反馈计数，须再乘 H。

这一陈述是 Jiang 等人的 OLIVE 结果在最优值可实现情形下的特例。原框架允许更一般的上下文决策过程及对有效候选类的比较；本节使用 MDP 便于与前文衔接。其奖励按整回合归一化，不能将该 H 依赖直接与前节每步奖励 $[0,1]$ 的界比较[96]。

OLIVE 将这个分解用于候选排除。它在尚未被数据否定的函数中选择初始预测回报最高的 f，再真实执行 π_f 检验回报。若预测与实测的差在规定阈值内，且 Q^* 一直未被排除，乐观预测就支持该策略近优；若差距大，则需要找到可检验的错误位置。沿轨迹将候选的相邻价值项抵消，得到

$$\mathbb{E} f_0(s_0, \pi_f(s_0)) - J_H(\pi_f) = \sum_{t=0}^{H-1} \mathcal{E}_t(f, f),$$

其中 J_H 表示该有限时域总回报。故至少一个时刻的 Bellman 误差足够大。算法按 π_f 走到这个时刻，再随机化该处动作，以重要性权重估计其他候选在同一访问分布下的误差，排除与数据不一致者。

置信阈值保证真实 Q^* 不被误删；分解结构和体积缩减论证保证不能无限产生新的独立错误方向。样本数中的动作因子来自检验时的动作覆盖，函数类大小以 $\log N$ 进入统一集中。但是寻找最乐观候选、检查并维护整个候选集合可能需要枚举 N 个函数；若 N 随输入维数指数增长，样本界小也不等于运行时间小。用神经优化器近似这些步骤，需要额外分析优化与判别误差。

表3.34还列出三种相邻概念。Eluder dimension 问的是：能否找到很长的新输入序列，使某两个候选在旧输入上几乎一致、在新输入上仍明显不同？它把“还需要多少次新辨识”与函数类的结构联系起来[97]。

[96] N. Jiang, A. Krishnamurthy, A. Agarwal, J. Langford, R. E. Schapire, *Contextual Decision Processes with Low Bellman Rank Are PAC-Learnable* In Proceedings of the 34th International Conference on Machine Learning, 2017, pp. 1704–1713

[97] D. Russo, B. Van Roy, *Eluder Dimension and the Sample Complexity of Optimistic Exploration* In Advances in Neural Information Processing Systems, 2013

复杂度	约束的对象	与本节分解的区别
Bellman rank	探索分布与候选 Bellman 误差之间的有限维因子分解	直接约束平均价值一致性，含范数参数和策略类
Witness rank	候选模型在测试函数下可被数据区分的程度	以模型失配的可观测证据为对象，依赖模型类与测试类
Eluder dimension	依次出现的新输入上还有多少未被旧观测约束的函数差异	点级预测的序贯独立性，不自动包含动力学与 Bellman 备份
Bellman–Eluder dimension	Bellman 残差类在允许访问分布上的序贯独立性	将点级辨识推广到残差及分布，须声明具体分布族

表 3.34　几种复杂度各自在控制什么。名称相近不意味着可以把其中一个维数直接代入另一个算法的样本界。

Witness rank 转向模型：数据能否通过某组测试函数见证候选转移与真实转移不一致，且这种证据能支撑策略改进？其条件不是只要求候选价值拟合得好。模型实现性、测试函数族及可执行的模型选择过程都要一并声明[98]。

Bellman–Eluder dimension 把序贯独立性施加到 Bellman 残差及访问分布上，覆盖多种可学习问题。相应 GOLF 或 OLIVE 分析对实现性、完备性或残差结构的要求随算法而异；低维数不自动解决非凸优化。读这类结果应依次核对“真实问题是否满足结构”“需要多少数据”“所需优化能否高效完成”，而不是用一个复杂度名词代替这三项检查[99]。

[98] W. Sun, N. Jiang, A. Krishnamurthy, A. Agarwal, J. Langford, *Model-Based RL in Contextual Decision Processes: PAC Bounds and Exponential Improvements over Model-Free Approaches* In Proceedings of the Thirty-Second Conference on Learning Theory, 2019, pp. 2898–2933

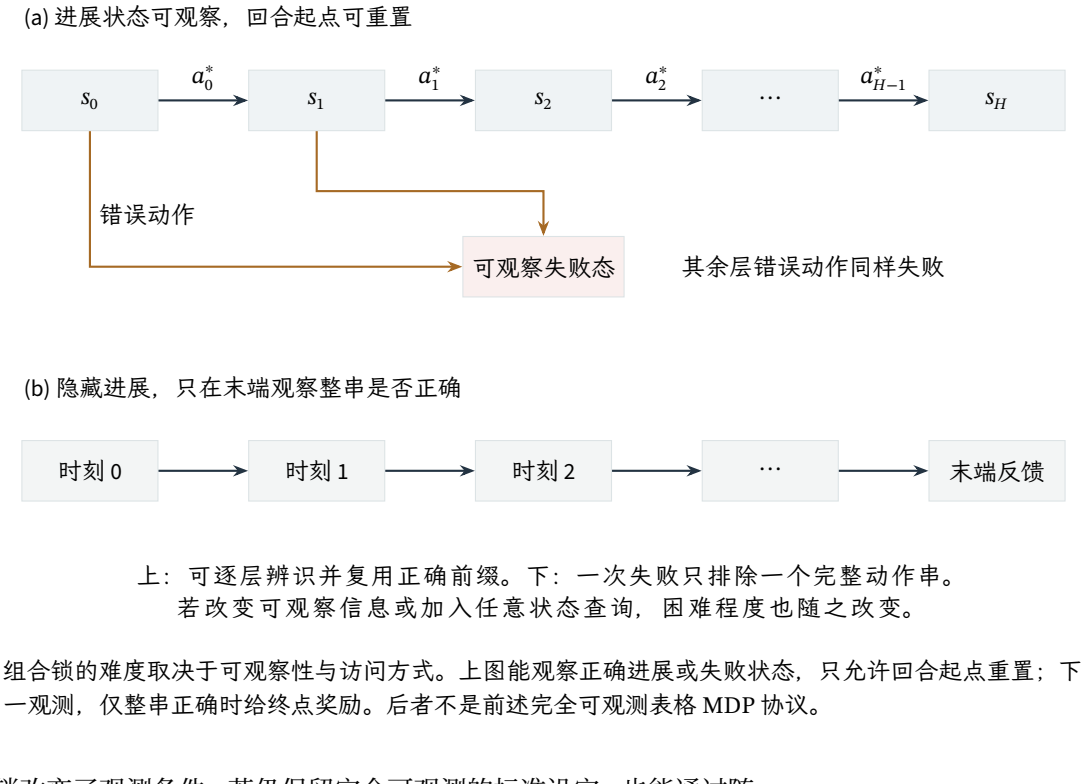
[99] C. Jin, Q. Liu, S. Miryoosefi, *Bellman Eluder Dimension: New Rich Classes of RL Problems, and Sample-Efficient Algorithms* In Advances in Neural Information Processing Systems, 2021

3.7.5 统计下界与计算—统计差距

上界给出某个算法在声明条件下足以使用的样本量，下界则限制任何算法至少需要的信息。组合锁展示了为什么必须先固定反馈条件：每步若能观察是否走对，就可逐层辨识正确动作；失败与进展若完全不可区分，直到末端才有奖励，一次尝试提供的信息就少得多。图3.30分开这两种接口，链长 H 本身并不能推出所有算法都需指数样本。

具体地，设每层 A 个动作、恰有一个正确动作，确定性转移，错误进入可观察的失败态，下一回合可重置到链首。记住已经验证的前缀后，每层至多试 A 个动作，每次走至该层耗 $O(H)$ 步，便有 $O(AH^2)$ 步的直接辨识策略；若还有任意状态生成模型查询，连重放前缀也可省去。逐步均匀随机策略偶然成功的概率是 A^{-H}，但这是该策略的表现，不是所有学习算法的下界。

若改成每步只观察时间、失败与进展状态隐藏、非末端奖励均为 0，未知正确动作串从 A^H 个可能串中均匀选出，那么一次失败仅排除本次完整尝试。每回合最多验证一个串，固定成功概率需要 $\Omega(A^H)$ 次尝试。这个教学问题族明确限制了反馈和重置能力；改变成可观察状态或允许查询隐藏状态，论证即不成立。



上：可逐层辨识并复用正确前缀。下：一次失败只排除一个完整动作串。
若改变可观察信息或加入任意状态查询，困难程度也随之改变。

图 3.30 组合锁的难度取决于可观察性与访问方式。上图能观察正确进展或失败状态，只允许回合起点重置；下图把两者隐藏为同一观测，仅整串正确时给终点奖励。后者不是前述完全可观测表格 MDP 协议。

组合锁改变了观测条件。若仍保留完全可观测的标准设定，也能通过随机奖励的微小差异产生辨识成本。我们构造两个只有一步的环境：近优输出必须选不同动作，单次奖励却难以区分环境。下面将决策要求转换成统计检验，给出可完整计算的样本下界。

定理 3.32 一步决策的辨识下界 设 $H = 1$、只有一个非终止状态和两个动作。环境 M_+、M_- 中动作 2 奖励均为 Bernoulli(1/2)，动作 1 奖励分别为 Bernoulli$(1/2+\Delta)$ 与 Bernoulli$(1/2-\Delta)$，其中 $0 < \Delta \le 1/4$。算法可自适应选择动作，共取得 n 个独立条件奖励样本，输出任意随机策略。若对两环境都以至少 $1-\delta$ 的概率输出 ϵ 近优策略，其中 $\epsilon = \Delta/4$、$0 < \delta < 1/4$，则

$$n \ge \frac{1}{16\Delta^2} \log \frac{1}{4\delta} = \frac{1}{256\epsilon^2} \log \frac{1}{4\delta}.$$

证明 令 $\hat{p}$ 为输出策略选择动作 1 的概率。在 M_+ 中 ϵ 近优要求 $\hat{p} \ge 3/4$；在 M_- 中要求 $\hat{p} \le 1/4$。故事件 $E = \{\hat{p} > 1/2\}$ 给出两环境检验，且 $\mathbb{P}_+(E^c) + \mathbb{P}_-(E) \le 2\delta$。

障碍	证据要求	能从中得出什么
信息不足	固定访问协议，构造难区分环境及检验下界	任何计算能力都不能凭不足数据达到指定保证
样本有效但计算昂贵	有限样本算法依赖枚举大候选类或难解优化	当前构造不高效；若要断言所有算法都计算困难，还须规约或计算假设
计算高效但条件更强	如已知线性特征、合法线性转移与可执行动作最大化	在该结构族可兼顾数据和计算，不代表一般网络满足条件

表 3.35 信息、统计与计算的边界。算法有昂贵子步骤不等于已经证明计算下界，预言机模型也必须与实际运行成本区分。

设 $\mathbb{P}_+, \mathbb{P}_-$ 为完整交互记录连同算法随机性的分布。条件于过去，算法使用同一动作选择机制；只有动作 1 的奖励分布不同。KL 的链式法则因此给出

$$D_{\mathrm{KL}}(\mathbb{P}_+ \| \mathbb{P}_-) = \mathbb{E}_+[N_1(n)]\ \mathrm{kl}(1/2+\Delta, 1/2-\Delta) \le 16 n \Delta^2.$$

最后一步利用 $\Delta \le 1/4$ 和 $\mathrm{kl}(1/2+\Delta, 1/2-\Delta) = 2\Delta \log[(1+2\Delta)/(1-2\Delta)] \le 16\Delta^2$。两分布检验不等式 $\mathbb{P}_+(E^c) + \mathbb{P}_-(E) \ge \frac{1}{2} e^{-D_{\mathrm{KL}}(\mathbb{P}_+\|\mathbb{P}_-)}$ 于是推出 $2\delta \ge \frac{1}{2} e^{-16 n \Delta^2}$，移项即得结论。 ■

证明把三个步骤接在一起：奖励均值只差 2Δ 使单次观测 KL 为 $O(\Delta^2)$；近优策略却必须作出不同选择；检验错误概率将两者连接成样本下界。这里使用的换测度与顺序辨识思路也见最佳臂识别的原始分析，但上面的常数和 $\epsilon = \Delta/4$ 是本书对这一教学问题对的直接推导[100]。

该下界只证明一个状态、两动作、一步任务中已经需要 ϵ^{-2} 量级数据，不声称导出了前述所有 S, A, H 因子。多状态 MDP 下界还需构造多个必须分别辨识的局部选择，并分析访问这些选择与长期收益放大的关系。算法渐近收敛与此不矛盾：无限数据最终能区分两个环境，并不回答在 n 次反馈内能否可靠分清。

表3.35总结了本节能支持的判断。OLIVE 展示一般结构下的样本可行性，LSVI-UCB 在更明确的线性条件下提供可实现的更新，两环境下界则限制任何算法的信息需求。它们各自回答一个问题；只有把访问能力、函数类、目标精度和计算方式一起写出，才有可比较的“可学习”结论。

3.8 算法评估和比较

实验需要把前述访问能力、表示和预算落实到可复核配置。同一任务上更高的测量回报，可能来自更新机制，也可能来自更多真实数据、计算、调参或部署搜索。比较前应明确这些差别和评价目标，再报告对应预算下的回报及不确定性；否则一条较高曲线不能区分这些解释。

预算量	建议计数方式	常见误读
真实环境步	累计实际环境转移；并行环境按各自转移数相加	一次向量化调用不等于一次转移，动作重复后的帧数另记
梯度步	按优化器更新次数，并分开行动者、评论家、模型	两个评论家的更新不能与单个网络的一步含混合计
重放比例	同时报 U/N_{env} 及 UB/N_{env}，U 为更新数、B 为批量	前者是更新次数比，后者是抽样条数比，数值相差 B 倍
模型样本	合成转移数、分支起点数与滚动长度分别记录	合成 100 万条不等于真实交互 100 万次
墙钟时间	固定硬件、并行度，分别记录采集、训练、评价及总耗时	只报网络更新时间会漏掉规划、仿真和数据等待
参数及内存	报可训练参数、目标网络与模型集成数量、峰值内存	相同参数数不等于相同计算，回放也占资源
部署预算	每次决策的模型查询、候选数、延迟分位数与硬件	训练时省样本可能换来每次动作的大量搜索

表 3.36　真实数据、数据重复利用与计算的不同单位。U, B 随阶段变化时应按各批实际大小累加，不只报一个最终配置值。

3.8.1 数据与计算预算

一条真实转移可以被 DQN 多次重放，也可以先训练模型，再产生很多合成经验。若只报“训练步”，就会把信息获取和重复计算混在一起，无法判断样本利用率或运行成本。表3.36分别计真实转移、优化更新、抽样条数和模型查询，训练与部署也单列。

可以在基准网格上比较表格 Q-learning 与学习模型的 Dyna，先固定相同的状态、动作、奖励、终止与起点规则。Dyna 的模型只能用已取得经验拟合，不能暗中访问本书给出的真实转移表。两者最终都按约定贪心策略部署，探索和学习率的搜索预算相同；Dyna 另报告每次真实转移后的模拟备份数。这里选择两种方法只是给出可复现的实验设计，不预先断定哪一个获胜。

一种预算视角固定真实交互数 N_{env}：在相同检查点冻结策略，用不进入训练缓冲的独立测试回合估计 J，比较相同信息预算下的决策质量。另一种固定总计算资源与墙钟期限：把模型拟合、模拟备份和真实环境执行都计入，比较期限内得到的策略。前者允许算法多花计算提高样本利用率，后者则要求为这些计算付出代价。两种比较回答不同问题，结果不必一致。

部署成本另外测量。网格中两者都可查表选动作；若改成 MPC 与 SAC 比较，每次 MPC 动作的候选搜索应计入部署预算，而 SAC 的训练开销不应被挪进这一指标。在线更新若与动作生成共享设备，还要报告它是否影响控制延迟。

图3.31给出两张曲线的作图协议，不包含实验结果。可预先约定 20 个独立训练种子、每个检查点 100 个独立测试回合；这些是教学协议的设定值，不是已经完成的运行。第 m 个种子在检查点的测试均值记为 $\overline{G}_m$，保存 $(N_{\mathrm{env}}, t_{\mathrm{wall}}, \overline{G}_m)$ 及测试原始回报，同一检查点分别投到两个横轴，图例

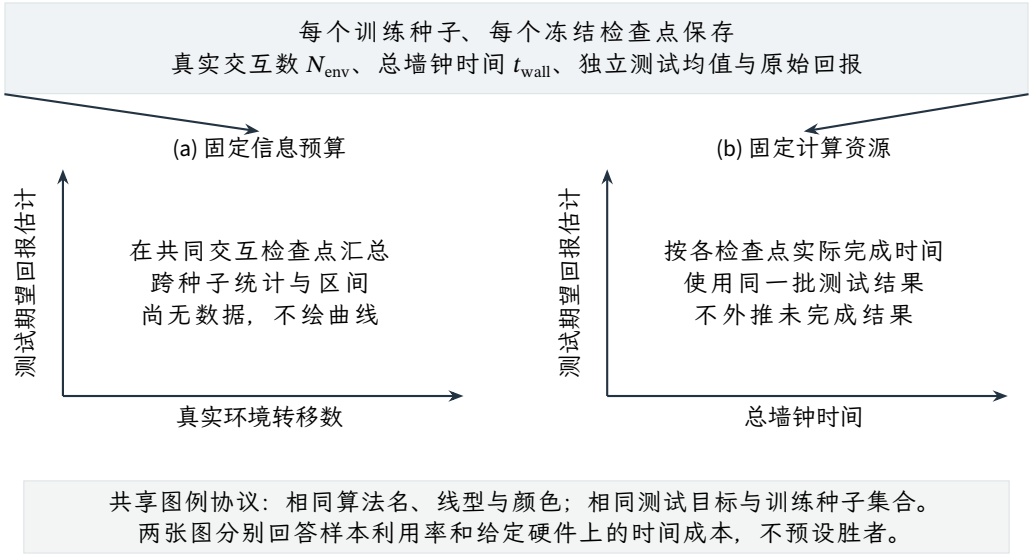


图 3.31 两种预算视角的作图协议，非实验曲线。每个真实检查点同时保留交互数、墙钟时间与测试统计，再分别投影到两张图；方法标识、测试目标和抽样单位保持一致。得到实测数据前不填曲线、误差带或排名。

始终使用同一算法名与线型。没有数据时不画领先曲线，也不以手绘趋势代替测量。

画学习曲线还应预先约定插值规则。不同种子的检查点不齐时，可在共同交互预算上使用最近已完成策略，不把尚未达到的结果外推到较小预算；时间轴同理。是否平滑、平滑窗口、失败运行与提前终止如何显示，都要留在作图配置中。曲线下面积若被用作汇总，积分区间与横轴单位也是指标定义的一部分。

3.8.2 统计报告与模型选择

固定一个训练后的策略测试 1000 回合，主要减少其环境回报估计的波动；重新训练 1000 次则还能观察初始化、探索和优化导致的策略差异。要评价算法而非一次幸运训练，必须分开这两个抽样层次，并明确置信区间覆盖哪一种平均性能。

记第 m 个独立训练运行的冻结策略为 $\pi^{(m)}$，第 n 次独立测试回报为 $G_{m,n}$。先在每个策略的 N_{test} 个回合内平均，估计这个产物的期望回报；再对 M 个训练运行平均，估计整个训练流程的平均性能：

$$\overline{G}_m = \frac{1}{N_{\text{test}}} \sum_{n=1}^{N_{\text{test}}} G_{m,n}, \qquad \overline{G} = \frac{1}{M} \sum_{m=1}^{M} \overline{G}_m.$$

$G_{m,n}$ 是一次轨迹结果，$\overline{G}_m$ 估计这个训练产物的期望性能，$\overline{G}$ 估计训练流程随机运行后的平均性能。置信区间应说明覆盖哪一个对象。表3.37对应这三个层次。

抽样单位	主要随机性与报告量	不能替代的统计工作
单次测试轨迹	初始状态、环境噪声和策略采样；报告回报、长度或成功事件	一条幸运轨迹不代表该策略的期望性能
固定训练产物	多测试回合的均值与区间	不反映重新训练是否会失败
独立训练运行	种子间分布、均值或稳健汇总及区间	增加同一种子的测试回合不能消除训练方差
多任务基准	每任务分数、明确归一化后的汇总及性能分布	同一模型跨任务测量可能相关，不能当成全部独立样本

表 3.37 实验统计的抽样单位。种子列表、测试环境随机数与任务抽样分别记录，置信区间不能只写一个百分比而不说明覆盖对象。

两层抽样的差别可以量化。若训练产物的真实期望回报方差为 τ^2，给定训练产物的轨迹方差再对产物平均为 σ^2，不同训练运行相互独立，且给定各自产物后测试轨迹条件独立同分布，则总方差公式给出

$$\operatorname{Var}(\overline{G}) = \frac{\tau^2}{M} + \frac{\sigma^2}{MN_{\text{test}}}.$$

增加 N_{test} 只压低第二项。学习曲线的相邻检查点来自同一次训练，具有相关性；逐点区间不是“整条曲线同时被覆盖”的置信带，不能用每点 95% 宣称整条曲线有 95% 覆盖。

最少应同时保留学习曲线、预先约定的最终检查点和全部运行的最终分数。跨任务平均前要说明归一化；均值敏感于极端高分，中位数可能掩盖大幅改善或退化，四分位均值（IQM）取排序后中间 50% 分数的平均，提供另一种稳健汇总，但它们没有共同的“正确排名”。还可报告性能分布 $\mathbb{P}(\text{归一化分数} > \tau)$ 随阈值 τ 变化的曲线，让读者看出优势发生在哪些分数区域。

区间重抽样也应匹配目标。若任务集合固定，按任务分层重抽各任务的训练运行；若关心新任务总体，还需说明任务抽样分布并在外层重抽任务。同一多任务训练产物的多个分数需以整组为单位保留相关性。少量种子下，任何区间估计仍可能很不稳定，应公开原始分数，而不是让一个窄色带制造精确感。Agarwal 等人的研究系统讨论了深度强化学习少运行数评价中的区间、IQM 和性能分布问题[101]。

示例 3.33 挑最好检查点造成的偏差 假设两个检查点的真实测试均值都为 0.6，各自的测量误差独立且以相同概率为 ± 0.1。预先固定最后一个检查点，报告值的期望仍为 0.6。若看完两次测试后挑较高者，则仅在两次都低时报告 0.5，其他情形报告 0.7，所以报告值期望为

$$\frac{1}{4}(0.5) + \frac{3}{4}(0.7) = 0.65.$$

[101] R. Agarwal, M. Schwarzer, P. S. Castro, A. Courville, M. G. Bellemare, *Deep Reinforcement Learning at the Edge of the Statistical Precipice* In Advances in Neural Information Processing Systems, 2021

> 被选策略的真实均值仍是 0.6。这 0.05 来自选择噪声，没有任何策略改善。

因此“最好检查点”可以是明确的模型选择协议，却不能在同一批测试数据上既选又报无偏性能。固定调参候选数、验证预算与选模规则，选择之后另用未参与选择的测试回合评估；若反复查看测试集并改变超参数，测试集已承担验证功能，应另留最终测试。第3.2.6节提到的 Rainbow 最好快照应按其原协议理解，不与固定最后检查点悄然混比。

消融也需相同预算。去掉组件后若释放大量计算，应说明是保持其他更新次数不变，还是把省下的计算重新分配；前者更接近固定实现条件下的组件作用，后者更接近固定资源下的系统比较。对失败运行不能只删去低分种子，算法性失败应按预先约定纳入分布；基础设施故障的重跑条件和次数另记。

3.8.3 基准协议与复现边界

使用同名环境也可能取得不同信息、执行不同动作或优化不同目标。以 ALE 为例，像素与模拟器内部状态提供的信息不同；动作重复、黏滞动作、随机起始空操作和生命损失处理还会改变动力学或回合边界。黏滞动作按规定概率继续上一动作，因而固定请求串不再机械复现同一轨迹。比较 Atari 结果时，需要记录 ALE 版本、ROM 校验值、包装器和黏滞概率，才能确定两种方法面对的是否为同一协议[102]。

Procgen 有 16 个程序生成的游戏环境，核心协议之一是限制训练关卡种子，再在未用于训练的关卡上评价。训练与测试关卡重合时测的是另一种泛化问题；难度分布、关卡数、种子区间和版本都要记录。原论文对样本效率和泛化分别给出协议，不能把无限关卡训练与有限关卡训练的分数混在一起[103]。

基准	观测与动作信息	随机性与划分	终止及版本记录
ALE	像素或内部信息、帧堆叠、动作集合、动作重复	黏滞动作、随机起始、训练与测试随机种子	真正游戏结束、生命损失包装、时间上限；ALE 版本、ROM 哈希
Procgen	像素、动作映射、包装器与网络输入处理	训练关卡数、种子区间、未见关卡及难度分布	回合结束与截断；包版本、游戏配置、关卡生成种子
连续控制	状态或像素、动作范围、控制频率与重复	动力学随机性、初始分布、任务或扰动划分	失败终止与时间上限；仿真器、模型文件及任务版本

表 3.38 影响算法可用信息、动力学或目标的基准协议。具体概率和重复次数应从实际配置读取，不把某个流行默认值写成基准的唯一规则。

连续控制还需区分状态输入与像素输入、控制周期与底层物理仿真步长、动作重复、奖励缩放以及失败终止。DeepMind Control Suite 与 Gym 中的相近身体模型未必有相同奖励、动作频率或终止条件，名字相似并不能建立直接可比性。其环境定义和任务设计应以具体版本为准[104]。

表3.38中的时间上限尤其容易改变学习目标。沿用第1章的区别，真实终止说明任务后继回报为 0；采样截断可能只表示当前记录到此为止。设基准网格中一条非终止转移奖励 -0.04，后继估值 0.8，$\gamma = 0.9$，若此处只是采样达到时间上限，正确自举目标为 0.68；错当终止则变成 -0.04，每次都漏掉 0.72。若任务本来就定义为到这个时限结束，则零自举才符合目标，且剩余时间通常要进入决策状态。

实现中应分别保存 `terminated` 与 `truncated` 的含义，并按任务目标确定自举掩码。自动重置的向量环境还须使用截断前的最终观测，不能把下一回合重置后的观测当成这条转移的后继。时间上限的两种语义及其对状态与自举的影响，有专门的原始分析[105]。

跨游戏原始分数的单位不同，不能直接把数值大小当成统一性能。若用随机与人类参照对每个游戏缩放，就需要同时固定参照值和测量协议。以 ALE 常见的人类归一化分数为例，

$$S_{\mathrm{HN}} = \frac{S_{\mathrm{agent}} - S_{\mathrm{random}}}{S_{\mathrm{human}} - S_{\mathrm{random}}}.$$

必须提供每个游戏的人类与随机参照值及其测量协议。若分母很小，少量原始分差会被放大；若参照顺序反常或分母为 0，应说明排除或替代规则，不能直接平均。教学值 $S_{\mathrm{agent}} = 30, S_{\mathrm{random}} = 10, S_{\mathrm{human}} = 50$ 对应 0.5，不是原始得分的“50%”；它表示从随机到人类参照差距的一半。是否截断到某范围也会改变跨任务汇总，需明确报告。

表3.39不是附在论文末尾的形式清单：每一项都可能改变结论。例如异步采样器延迟会增大行为策略与目标策略的差别，回放保留期会改变访问分布，模型更新频率会改变合成经验的失配程度。采样服务与分布式存储

[104] Y. Tassa, Y. Doron, A. Muldal, T. Erez, Y. Li, D. de Las Casas, D. Budden, A. Abdolmaleki, J. Merel, A. Lefrancq, T. Lillicrap, M. Riedmiller, *DeepMind Control Suite*, 2018, arXiv: 1801.00690

[105] F. Pardo, A. Tavakoli, V. Levdik, P. Kormushev, *Time Limits in Reinforcement Learning* In Proceedings of the 35th International Conference on Machine Learning, 2018, pp. 4045–4054

复现记录	最少需要保存的内容
代码与配置	提交标识、依赖锁定、环境与包装器版本、全部实际展开后的超参数
数据与随机性	真实/合成数据来源及规模、训练与评价种子、初始分布、训练测试划分
更新语义	采样策略版本、目标网络与策略更新频率、终止掩码、重放比例及样本寿命
模型选择	候选与调参预算、验证集、停止及检查点选择规则、最终独立测试流程
失败处理	失败定义、原始结果、基础设施重跑规则与实际重跑次数
资源与产物	硬件、精度、并行度、墙钟和部署预算、模型检查点、逐运行日志与作图脚本

表 3.39 最小复现记录。分布式系统实现可在系统卷展开，但会改变采样分布或更新目标的接口必须在算法实验中说明。

主要接口	经验主要更新什么	最终动作主要来自哪里
无模型价值学习	MC/TD 回报、动作值与其函数表示	对动作价值贪心或按约定探索，如 SARSA、Q-learning、DQN
无模型策略优化	策略参数，通常另有评价策略的评论家	更新后的策略，如 PPO、SAC；离策略校正与覆盖仍需检查
基于模型的价值学习与规划	动力学、奖励及规划需要的价值或搜索先验	Dyna 更新后的价值控制，或 MPC、MuZero、TD-MPC 的当前规划结果
基于模型的策略优化	动力学以及用模型梯度或合成数据训练的行动者、评论家	更新后的策略，如 PILCO、Dreamer、MBPO；潜在状态推断仍可调用模型

表 3.40 四种组合共享探索、函数表示与时间抽象条件。混合系统按实际数据和决策流说明，不要求每个系统只学习一种对象。

怎样工程实现留给系统卷；本章要求先把这些对数据和目标的影响记录清楚。

3.9 本章小结

回到章首网格问题，一次动作只能给出一次奖励和落点，我们既要用它估计长期后果，也要决定下一次去哪里取得证据。本章的四种组合给出了不同计算接口：直接更新价值或策略，或者先学模型，再用预测支持这些更新。表3.40按主要更新对象和最终动作来源汇总；混合系统应沿实际数据流解释，不能只凭出现了某个网络就归类。

这些接口都处在同一反馈中。关键动作样本不足会使回报、转移或价值估计不可靠，估计误差又通过贪心选择或策略更新改变动作，新的访问分布进一步决定哪些误差能被修正。MC 用完整随机回报，TD 以当前估值自举，离策略评价按支持和概率比复用旧数据，选择的是不同的数据需求与估计取舍。双重采样反例提醒我们先核对损失是否对应目标；资格迹和优势估计改变信用传播长度，却不能补出未取得的奖励信息。

是否得到可靠策略，取决于误差能否转到实际决策分布。统一动作值误差给出贪心策略损失界，低训练均方误差却可能漏掉关键岔路；性能差恒等式使用新策略占用下的优势，旧批次代理必须控制分布替代；模拟界需要奖励与转移误差覆盖被选策略，而搜索和想象优化恰会寻找高估区域。

时间抽象同样保留这些要求：Option 用 γ^K 维持原子时间目标，高层少做几次决策，并不意味着真实交互、内部控制学习或执行风险同比减少。

有限样本分析进一步把这些条件写成访问协议和问题结构。UCBVI 依赖表格计数，LSVI-UCB 依赖已知特征及线性奖励转移，OLIVE 依赖候选误差的有限维分解；它们分别约束不同问题族，不能拼成任意神经算法的保证。实验相应地需要分别记录真实样本、重复更新、模型计算、选模和部署预算，并用独立训练运行区分训练波动与固定策略的测试波动。

因此，环境模型未知时仍可通过经验评价和改进策略，但一次更新可计算，尚不足以保证有限预算下近优。算法形式规定怎样利用记录，访问能力规定能取得什么记录，函数类规定如何共享信息，预算则限制辨识和求解能做到哪里；四者共同决定本章答案的范围。后续各章改变信息、反馈、任务、参与者或行为要求，复用这里的部件时也需重新检查其数据来源、优化目标和保证条件。

第 4 章

信息受限下的强化学习

一辆小车驶近岔路口，摄像头清楚地拍到了它的位置，控制器仍可能无法决定怎样转向。如果画面没有显示小车向哪一侧滑动，控制器需要借助过去的观测辨认当前运动状态。如果位置和速度都已知，但日志从未记录某种转向动作，学习者需要判断现有经验能否说明该动作的后果。这两种困难需要不同的信息：记忆可以保留过去的线索，却不能补出从未尝试的行为；反复训练可以重新利用日志，却不能找回未被记录的线索。

第 3 章已经说明怎样从经验估计价值、优化策略和学习模型。本章考察这些方法在信息受限时还能使用到哪一步。状态不可见时，我们要从当前观测转向完整历史，或构造保留决策所需信息的历史表示。经验固定时，我们要先判断日志是否足以确定候选策略的价值，也就是价值是否可识别，然后才能讨论估计和改进。图 4.1 将这两条认识路径分开。离线部分可观测问题同时受到两类限制：既要检查历史中留下了哪些线索，也要检查收集者依据什么选择了日志中的动作。

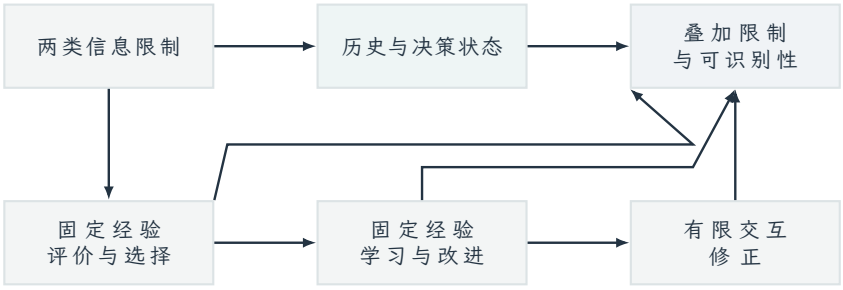


图 4.1　本章的阅读依赖。箭头表示理解后项需要前项建立的概念，不表示算法的执行顺序。历史表示说明行动时能依据什么，固定数据评价说明已有经验能支持哪些判断；两者共同限制离线部分可观测问题中的策略结论。

4.1　两类信息限制

4.1.1 决策所依据的状态信息

第 1 章的马尔可夫条件针对完整状态 s_t：给定它和当前动作，就能描述下一步的条件分布，无须再查询更早的经历。摄像头取得的 o_t 只是状态的一部分信息，给定同一画面和动作，后果仍可能随未见的速度而变化。因此，执行策略不能直接沿用以 s_t 为输入的规则，而要考虑此前已取得的记录。一步记录 (o_t, a_t, r_t, o_{t+1}) 按真实交互时刻 t 排列：先看到 o_t，再执行 a_t，随后取得奖励 r_t 和下一观测。这个时间下标不表示训练中的梯度更新次数。

定义 4.1　决策历史　时刻 t 的完整记录历史按时间排列行动前已经取得的观测、动作和奖励，写为

$$h_t = (o_0, a_0, r_0, \dots, a_{t-1}, r_{t-1}, o_t).$$

历史条件策略 $\pi(a \mid h_t)$ 以行动前已获得的观测、动作和奖励为依据。当前观测策略的输入仅为 o_t；长度为 L 的窗口策略仅保留最近 L 步记录，并须约定窗口在回合边界处怎样构造。

历史中也保留奖励，因为奖励可能帮助辨认状态。例如，碰撞后返回的奖励可以说明小车触及了画面中看不见的障碍；删去它，就可能丢掉下一次决策需要的线索。这里保留的都是已经发生的反馈，未来才揭示的状态或奖励不能提前交给当前策略。

示例 4.2　相同位置与不同记忆　考虑一个独立教学任务。小车的真实状态包括位置 x_t 和速度 v_t，摄像头只给出位置。同样看到 $x_t = 0$ 时，若 $v_t = 1$，所需制动方向与 $v_t = -1$ 时相反。为判断运动方向，可以比较相邻位置。在无噪声、采样间隔为 1 且速度在相邻采样间不变的简化条件下，$v_t = x_t - x_{t-1}$；两次位置观测足以恢复速度，单帧没有这项信息。

再考虑线索出现得更早的岔路任务。回合开始时，提示 $c \in \{L, R\}$ 以相同概率显示；小车随后经过 $L + 1$ 步外观相同的走廊，途中只能前进，奖励均为 0。出口处选中 c 指示的方向得 1，选错得 0。本例及后文均按不折扣的回合成功奖励比较，其期望就是成功概率，不采用默认折扣回报。完整历史策略可以记住提示，期望成功奖励达到 1。最近 L 步窗口已经看不到提示，固定的前进动作也不能编码提示，因此这类策略的最好期望成功奖励为 $1/2$。

位置任务只需多保留一帧，便能补出缺失的速度；岔路任务却说明，任意预先固定的窗口都可能因线索延迟更长而失效。表示是否足够，取决于它有没有保留区分动作后果的信息，而不是输入序列单纯有多长。

4.1.2 学习能够访问的经验

现在让日志完整记录小车的位置和速度。如果收集者在某个状态从不向左转，我们仍可能不知道在那里左转会怎样。缺口不在单条记录的字段，而在整批记录涉及的行为。分析可用经验时，必须分别检查记录是否完整、收集行为覆盖了哪里，以及学习者能否主动补采样。

定义 4.3　经验访问协议　固定经验协议将可用材料限定为给定数据集 $\mathcal{D}$ 及声明可用的元数据，训练和选模期间都不允许查询真实环境。**有限新增交互**协议允许在约定的轮次和预算内补充真实经验；每轮可执行的策略、重置权限和专家帮助权限均由协议规定。**持续在线交互**协议允许策略根据经验不断更新并继续收集数据，但重置、传感和测试权限仍须明确，不能据此假定可以从任意状态采样。

固定日志即使回放一百万轮，真实访问过的状态和动作也不会增加，改变的只是算法利用这些记录的方式。学习模型生成一百万条模拟转移，同样没有新增真实查询。表 4.1 沿用完整记录位置和速度的小车任务，对照交互权限改变后能够取得的证据。

协议	记录字段	行为覆盖	主动采样权限	评价查询权限
固定经验	位置、速度、动作、奖励和回合边界	仅原日志的收集行为	无真实调用、无重置	只能离线估计；不能试跑候选
有限新增	原字段加策略版本、轮次和查询用途	原日志加预算内新增行为	每轮限定步数；重置单列计数	允许的测试也扣除预算
持续在线	同样记录状态与行为元数据	随收集策略持续变化	在可达轨迹上继续行动；任意状态重置仍需授权	独立测试须保留其数据职责与成本

表 4.1　同一完全可观测小车任务中的三种经验协议。完整字段不能补齐未尝试的动作；可以继续交互，也不意味着可以像调用生成模型那样从任意指定状态采样。

4.1.3 观测完整性与数据访问权的组合

小车能否取得完整状态，并不决定训练者能否继续驾驶它。只见位置的控制器可以被允许主动加减速，借反馈辨认运动方向；已经记录位置和速度的日志也可以禁止新增试验。表 4.2 将观测完整性与交互权限交叉排列，得到四种条件。

下节先固定执行时不能直接看到状态的条件，考察怎样由已有观测形成决策依据。第 4.3、4.4 节改回完全可观测任务，分别检查固定日志怎样支持评价和学习。第 4.6 节再将两类限制叠加，重新核对成立条件。分开讨论以后，才能辨清失败来自历史压缩遗漏线索，还是来自日志没有覆盖目标动作。

执行观测	可新增真实交互	只有固定经验
完整状态	位置、速度均可见，可继续控制小车	状态字段完整，但只能使用已有驾驶日志
部分观测	只见位置，可主动探查，构成在线 POMDP	只见位置的固定轨迹，构成离线 POMDP

表 4.2　观测完整性与数据访问权可以交叉组合。允许少量新增经验只放宽访问权限，不改变观测类型；表中的 POMDP 将在下节正式定义。

4.2 决策信息不完整下的强化学习

4.2.1 从当前观测扩展为观测历史

回到例 4.2 的出口：同一画面下，早期提示为左时应向左，为右时应向右。**观测混叠**（observation aliasing）就是不同决策处境对应同一个可见输入，因而仅凭该输入无法区分它们。完整隐藏状态可以满足马尔可夫条件，观测过程却未必满足；我们需要同时描述状态怎样演化、观测怎样产生。图 4.2 将这两种关系分开，也显示相同当前观测可以来自不同历史。

定义 4.4　有限部分可观测马尔可夫决策过程　部分可观测马尔可夫决策过程（partially observable Markov decision process, POMDP）分别描述环境的隐藏状态和智能体取得的观测。本章采用有限状态集 $\mathcal{S}$、动作集 $\mathcal{A}$、观测集 $\mathcal{O}$、初始分布 ρ_0 与有限时域 H；为使用有限求和，暂将奖励取值也限定在有限集 $\mathcal{R}$。

初始状态 $s_0 \sim \rho_0$ 生成观测 $o_0 \sim O_0(\cdot \mid s_0)$。在时刻 t，智能体依据 h_t 选择 a_t，环境随后生成 s_{t+1} 及反馈 $y_{t+1} = (r_t, o_{t+1})$。将下一状态与反馈的条件分布合写为已知联合核

$$K(s', y \mid s, a) = \mathbb{P}(s_{t+1} = s', y_{t+1} = y \mid s_t = s, a_t = a).$$

对反馈求和得到转移核 $P(s' \mid s, a) = \sum_y K(s', y \mid s, a)$；按奖励值加权所有后果，得到期望奖励 $R(s, a) = \sum_{s', r, o'} r K(s', (r, o') \mid s, a)$。奖励有界，采用回报 $\sum_{t=0}^{H-1} \gamma^t r_t$，其中 $0 \le \gamma < 1$，终端价值取 0。

联合核保留了奖励与观测可能共享的隐藏信息，只有满足相应独立性时，才可进一步分解为转移和观测模型。与这一信息约定对应，执行策略写作 $\pi_t(a \mid h_t)$；仅使用当前观测的 $\pi_t(a \mid o_t)$ 限制了可选择的策略。我们保留时刻 t，因为有限时域中剩余时间也会影响动作选择，即使对隐藏状态的推断相同也如此。

仿真器有时能在训练日志中给出 s_t，帮助训练评论家或表示。但部署时若只能取得 o_t，执行策略就不能读取这一特权状态，评价时也须提供部署真正可用的历史。要利用状态模型而不直接观测状态，可以推断当前状

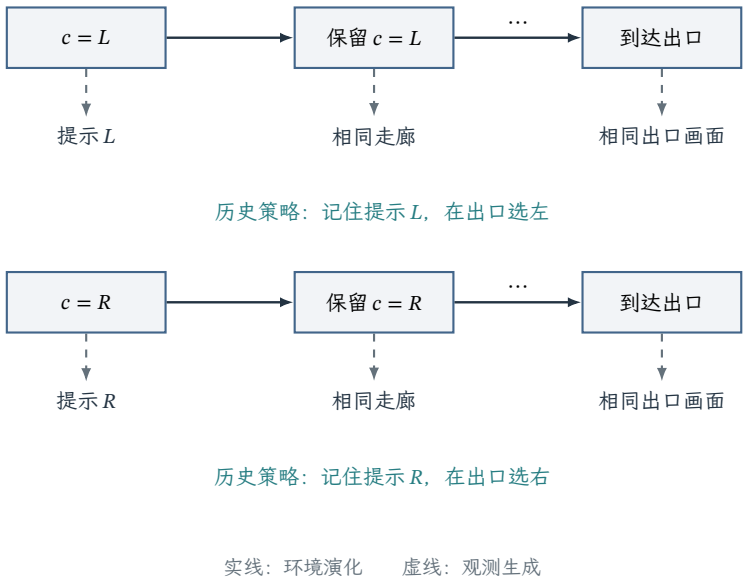


图 4.2 早期提示任务中的两条可能轨迹。实线描述隐藏状态演化，虚线描述观测生成，途中固定为前进的动作未画出。出口画面相同，旁边单列的历史策略却因记住不同提示而选择相反方向；这些动作不属于观测。

态的概率分布；下面的信念方法正是通过这一分布连接推断与决策，经典 POMDP 论述也采用这一思路[1]。

[1] L. P. Kaelbling, M. L. Littman, A. R. Cassandra, *Planning and Acting in Partially Observable Stochastic Domains* In Artificial Intelligence, 1998, vol. 101, no. 1–2, pp. 99–134

4.2.2 将观测历史压缩为决策状态

完整历史保留了已记录的线索，但输入和存储都随时间增长。压缩历史时，我们关心的是哪些信息会改变行动后果的预测，而不是能否复原每个过去细节。模型已知时，可以将历史转换为当前各个可能状态的概率。这样的概率分布称为信念状态，作用是保留当前状态的不确定性。

定义 4.5 信念状态 给定 POMDP 与完整记录历史，信念状态（belief state）定义为

$$b_t(s) = \mathbb{P}(s_t = s \mid h_t), \qquad b_t \in \Delta(\mathcal{S}),$$

其中 $\Delta(\mathcal{S})$ 是 $\mathcal{S}$ 上的概率单纯形，即所有状态概率非负且总和为 1 的分布集合。b_t 是给定历史后的后验分布，不表示另一个物理状态；只留下 $\arg\max_s b_t(s)$ 得到的点估计也不等于信念。

推断从回合开始便已发生。对于具有正概率的初始观测 o_0，按初始分布与观测似然加权并归一化，得到 $b_0(s) = \rho_0(s)O_0(o_0 \mid s) / \sum_{\bar{s}} \rho_0(\bar{s})O_0(o_0 \mid \bar{s})$；仅当初始观测不提供状态信息时，$b_0$ 才可直接取为 ρ_0。

如果把“障碍在左侧的概率为 0.6”直接改成“障碍在左侧”，右侧仍有 0.4 概率这一信息就消失了。碰撞成本很高时，这部分概率可能改变应选的动作。要说明保留完整分布为何足以支持控制，需要证明：预测奖励、更新状态推断和比较动作，都可以只使用信念完成。

定理 4.6　精确信念对最优控制充分　考虑定义 4.4 中的已知有限 POMDP，并假设动作选择仅依赖完整记录历史与独立的策略随机数。每个时刻 t 的最优历史价值都能写成 $V_t^*(h_t) = U_t^*(b_t)$，且存在仅以 (t, b_t) 为依据的最优策略。

证明　先检查信念能否预测一个动作的后果。固定正概率历史 h_t 并选择 a；由于动作只依据该历史和独立随机数，给定历史后的动作本身不再透露隐藏状态。按当前各状态的概率加权联合核，全概率公式给出

$$\mathbb{P}(s_{t+1} = s', y_{t+1} = y \mid h_t, a) = \sum_s b_t(s) K(s', y \mid s, a).$$

为预测可见反馈，将上式对隐藏的下一状态 s' 求和，得到 $q(y \mid b_t, a) = \sum_{s,s'} b_t(s) K(s', y \mid s, a)$；将奖励取期望，得到 $\bar{R}(b_t, a) = \sum_s b_t(s) R(s, a)$。反馈概率和奖励期望都由 (b_t, a) 确定。

反馈出现后还需要更新推断。对 $q(y \mid b_t, a) > 0$ 的反馈，以其概率归一化状态与反馈的联合概率，贝叶斯公式给出

$$b_{t+1}(s') = \frac{\sum_s b_t(s) K(s', y \mid s, a)}{q(y \mid b_t, a)} =: \tau(b_t, a, y)(s').$$

新信念只需旧信念、动作和新反馈便可算出，这就是后验递推闭合；已经压缩的其余历史无需再读。零概率反馈不贡献期望，因此任意指定这些反馈上的 τ 都不改变价值。

最后用反向归纳检查最优动作比较。终点满足 $V_H^*(h_H) = 0$，可令 $U_H^*(b) = 0$。假设 $t+1$ 时已有 $V_{t+1}^*(h) = U_{t+1}^*(b(h))$；那么在 t 时选择 a，当前奖励加上按可能反馈加权的最优继续价值为

$$\bar{R}(b_t, a) + \gamma \sum_y q(y \mid b_t, a) U_{t+1}^*(\tau(b_t, a, y)).$$

上式仅依赖 b_t 与 a。动作都来自有限动作集，按期望回报从中取最大值，便定义了 $U_t^*(b_t)$ 并完成这一步归纳。在每个 (t, b) 处选取最大化动作，以固定规则处理平局，就构造出达到该值的信念策略。归纳到 $t = 0$，结论成立。 ■

这一结果说明最优控制不必保留信念以外的历史，并没有要求所有历史策略都在相同信念下选择同一动作。控制器可以故意按一个与未来无关的旧观测切换动作；这只是它使用了额外历史，不影响最优信念策略的存在。

上述构造需要已知模型；模型未知时，精确后验也不能直接计算。学习型潜在信念尝试用 $\boldsymbol{z}_t$ 编码隐藏状态的不确定性。另一种选择是**预测状态表示**（predictive state representation, PSR），用若干未来试验发生的预测概率概括历史。“试验”包含指定的未来动作和随后要观察的反馈，因此只预测收集策略自然产生的下一帧还不够。若这些概率能够递推所有相关试验，就可不必为隐藏状态赋予语义名称；表示是否有限维、能否从数据学习，仍依赖结构条件[2]。

[2] M. L. Littman, R. S. Sutton, S. Singh, *Predictive Representations of State* In Advances in Neural Information Processing Systems, 2001

选择学习目标时，还要明确表示对什么问题充分。表 4.3 分别考察未来反馈、固定策略价值和最优控制。例如，在两个隐藏状态中，“始终停止”的价值均为 0，但向左、向右的奖励恰好相反。常数表示能准确预测停止策略的价值，却无法帮助选择转向动作。固定策略价值充分，不能据此推出改进所需的充分性。

充分性要求	必须保留的量	动作或策略范围	仍可丢失什么
未来反馈预测充分	各允许动作试验下的未来反馈联合分布与可递推状态	声明的全部试验，通常跨多个动作与时域	对这些预测无影响的历史细节与隐藏状态名称
给定策略价值充分	给定 π 和奖励下的条件期望回报	只要求该 π 的继续行为；还需说明其执行输入	其他动作的价值、完整反馈分布
最优控制充分	允许策略类中达到最优值所需的动作比较与更新	所允许的控制行为；依赖任务与时域	不影响最优动作的预测细节

表 4.3　三种充分性对应不同问题。固定策略的回报预测正确，仍可能缺少换策略或换奖励所需的信息；已知 POMDP 中的精确信念则具有最优控制充分性的依据。

4.2.3 新观测到来后的决策状态更新

信念充分性证明中，每次取得反馈都要生成新信念。实际计算时，给定已执行的 a_t 和收到的 $y_{t+1}=(r_t,o_{t+1})$，先遍历可能的前态，用旧信念加权联合核，得到 $\widetilde{b}_{t+1}(s')=\sum_s b_t(s)K(s',y_{t+1}\mid s,a_t)$。这是下一状态与该反馈同时出现的概率，尚未归一化。再对所有下一状态求和，算出模型赋予该反馈的总概率；以它为分母，得到给定反馈后的状态分布：

$$b_{t+1}(s')=\frac{\sum_s b_t(s)K(s',y_{t+1}\mid s,a_t)}{\sum_{\bar{s}}\sum_s b_t(s)K(\bar{s},y_{t+1}\mid s,a_t)}. \tag{4.1}$$

这个条件分布只在分母为正时有定义。真实反馈若在模型中概率为 0，滤波器便无法按上式归一化，需要检查模型或传感假设是否与实际过程失配。

若希望先预测状态、再单独用观测校正，就需要对联合核增加条件。假设 $K(s',(r,o')\mid s,a)=P(s'\mid s,a)O(o'\mid s',a)p(r\mid o',a)$，这表示给定 o' 与 a 后，奖励不再透露前后状态的信息。此时奖励项在分子分母中相同，可以约去；先对前态加权转移核，再按新观测的似然重新加权和归一化，得到

$$b^{-}_{t+1}(s')=\sum_{s}P(s'\mid s,a_t)b_t(s),\qquad (4.2)$$
$$b_{t+1}(s')=\frac{O(o_{t+1}\mid s',a_t)b^{-}_{t+1}(s')}{\sum_{\bar{s}}O(o_{t+1}\mid \bar{s},a_t)b^{-}_{t+1}(\bar{s})}.$$

碰撞奖励若由隐藏状态决定且提供了观测以外的线索，这一分解条件便不成立，更新时仍须保留奖励。

有限状态可以直接更新每个状态的概率；连续状态则需要适合其分布结构的表示。在线性高斯系统中，后验始终是高斯分布，只需存储均值和协方差。设 $\boldsymbol{x}_{t+1}=\boldsymbol{A}\boldsymbol{x}_t+\boldsymbol{B}\boldsymbol{u}_t+\boldsymbol{w}_t$，$\boldsymbol{o}_{t+1}=\boldsymbol{C}\boldsymbol{x}_{t+1}+\boldsymbol{v}_{t+1}$；其中初始状态为高斯，过程噪声与观测噪声是相互独立的零均值高斯量，协方差分别为 $\boldsymbol{W},\boldsymbol{N}$，并与初始状态独立；另行记录的奖励暂不提供额外状态信息。当前后验为 $\mathcal{N}(\boldsymbol{m}_t,\boldsymbol{\Sigma}_t)$ 时，Kalman 滤波先传播均值和协方差，再用实际观测与预测观测的差修正它们。增益按预测不确定性和观测噪声决定修正幅度，计算为

$$\begin{aligned}
\boldsymbol{m}^{-}_{t+1}&=\boldsymbol{A}\boldsymbol{m}_t+\boldsymbol{B}\boldsymbol{u}_t, & \boldsymbol{\Sigma}^{-}_{t+1}&=\boldsymbol{A}\boldsymbol{\Sigma}_t\boldsymbol{A}^{\top}+\boldsymbol{W},\\
\boldsymbol{L}_{t+1}&=\boldsymbol{\Sigma}^{-}_{t+1}\boldsymbol{C}^{\top}(\boldsymbol{C}\boldsymbol{\Sigma}^{-}_{t+1}\boldsymbol{C}^{\top}+\boldsymbol{N})^{-1},\\
\boldsymbol{m}_{t+1}&=\boldsymbol{m}^{-}_{t+1}+\boldsymbol{L}_{t+1}(\boldsymbol{o}_{t+1}-\boldsymbol{C}\boldsymbol{m}^{-}_{t+1}),\\
\boldsymbol{\Sigma}_{t+1}&=(\boldsymbol{I}-\boldsymbol{L}_{t+1}\boldsymbol{C})\boldsymbol{\Sigma}^{-}_{t+1}.
\end{aligned}\qquad (4.3)$$

这里要求创新协方差可逆；创新就是实际观测相对预测观测的差。增益 $\boldsymbol{L}_{t+1}$ 按两种不确定性的大小分配预测与新观测的权重。递推之所以精确，是因为线性高斯条件使后验保持高斯，而非均值和协方差能够代表任意分布[3]。

[3] R. E. Kalman, *A New Approach to Linear Filtering and Prediction Problems* In Journal of Basic Engineering, 1960, vol. 82, no. 1, pp. 35–45

示例 4.7　一次标量滤波　用标量教学系统 $x_{t+1}=x_t+u_t+w_t$、$o_{t+1}=x_{t+1}+v_{t+1}$ 核算一次更新。当前 $m_t=0$、$\Sigma_t=1$，令 $u_t=1$、$W=N=1$，随后观测到 2。状态预测为 $m^{-}_{t+1}=1$、$\Sigma^{-}_{t+1}=2$，由此算得增益 $2/3$。观测比预测大 1，校正得到 $m_{t+1}=1+(2/3)(2-1)=5/3$、$\Sigma_{t+1}=2/3$。方差尚未归零，所以 $5/3$ 是后验均值，不是已知的真实位置。

显式模型若不可信，就不能直接依靠上述精确滤波。可以改为从数据学习递推记忆 $\boldsymbol{z}_{t+1}=f_{\theta}(\boldsymbol{z}_t,a_t,r_t,o_{t+1})$，也可以保留历史，再由注意力网络重新计算 $\boldsymbol{z}_t$。图 4.3 对照了两种计算方式。输入序列必须保持同一轨迹的

时间关系，记忆按协议在回合开始重置；任意训练片段的开头未必是回合开始，不能在那里直接清零。

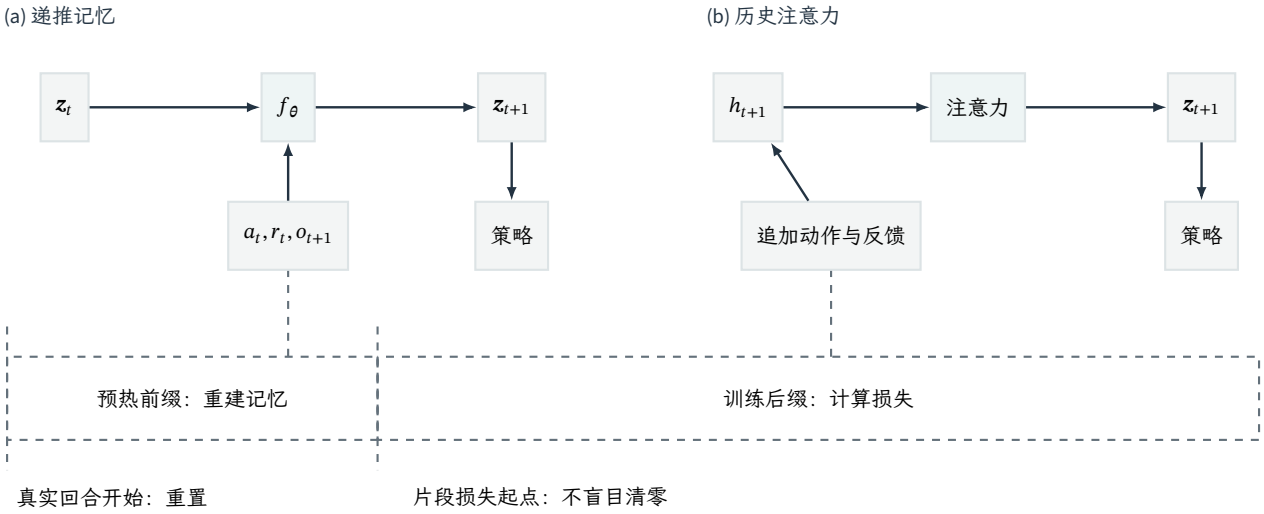


图 4.3 递推记忆与历史注意力的输入和更新。实线描述表示与策略的计算，虚线标出训练片段及边界。预热前缀用于恢复损失起点处的记忆，不计算其训练损失。图示片段从真实回合开始；回合中部片段需用已保存状态或更早前缀初始化，片段边界本身不构成重置依据。

DRQN 将循环状态加入价值网络，使前帧信息可以传到后帧。相对于堆叠有限帧，它改变了历史的保存方式，价值目标仍采用时序差分学习[4]。序列进入重放后，还要处理参数变化导致的表示漂移和旧隐藏状态，R2D2 分析了这些问题。截断反向传播只限制梯度跨越多少步，并未说明更早的历史无用。burn-in 即预热，先运行片段前缀恢复隐藏状态，再在后缀计算损失。也可以保存收集时的隐藏状态，减少从零启动的偏差；但网络参数更新后，保存的状态可能已不适合当前网络[5]。

注意力模型也可以跨片段保存信息，GTrXL 通过门控等结构调整适配强化学习优化。外部记忆则将历史写入独立存储，再按需读取。增加这些保存能力会带来缓存、读写和训练成本。更长的上下文或更低的预测损失，只描述输入范围或拟合结果，尚不能证明表示满足定理 4.6 的条件。

[4] M. Hausknecht, P. Stone, *Deep Recurrent Q-Learning for Partially Observable MDPs* In AAAI Fall Symposium on Sequential Decision Making for Intelligent Agents, 2015

[5] S. Kapturowski, G. Ostrovski, J. Quan, R. Munos, W. Dabney, *Recurrent Experience Replay in Distributed Reinforcement Learning* In International Conference on Learning Representations, 2019

4.2.4 基于决策状态的策略求解与动作选择

信念更新给出当前各状态的概率，我们还需要据此决定动作。比较时要平均可能状态的后果，并允许后续动作随新反馈改变，不能先挑一个最可能状态当成真相。信念 MDP（belief MDP）把可计算的信念本身作为完全可见的决策状态。其即时奖励为 $\bar{R}(b,a)=\sum_s b(s)R(s,a)$，反馈概率为 $q(y\mid b,a)=\sum_{s,s'} b(s)K(s',y\mid s,a)$，状态转移通过 $\tau(b,a,y)$ 实现。要计算剩余时域的最优回报，可以对有限动作集 $\mathcal{A}$ 中的每个动作，加上即时奖励

和按反馈概率加权的继续价值，再选最大的期望回报。第 2 章的 Bellman 关系由此写成

$$U_t^*(b) = \max_a \left\{ \bar{R}(b,a) + \gamma \sum_y q(y \mid b,a) U_{t+1}^*(\tau(b,a,y)) \right\}, \qquad U_H^* = 0. \tag{4.4}$$

反馈不可由控制器挑选，必须逐个更新信念、计算继续价值后按发生概率取期望。一般不能用 $U_{t+1}^*(\mathbb{E}[b_{t+1}])$ 替代 $\mathbb{E}[U_{t+1}^*(b_{t+1})]$，因为后续动作依据实际反馈而非平均反馈选择；先平均信念会丢掉这种适应机会。

示例 4.8　Tiger 中的倾听、更新与开门　Tiger 任务有两扇门，一侧藏着危险，另一侧可以获得奖励。隐藏状态 $s \in \{L, R\}$ 表示危险的方向。打开安全门得 10，打开危险门得 -100，随后回合终止；倾听得 -1，状态不变，以 0.95 的概率报告正确方向。令初始 $b_0(L) = b_0(R) = 1/2$，最多行动两次，$\gamma = 0.9$，时域结束后价值为 0。这些数值与两步终止规则仅用于教学，不代表所有 Tiger 版本。

先比较不获取信息的动作。直接打开任意一扇门，按初始危险概率加权，期望奖励都是 $(1/2)10 + (1/2)(-100) = -45$。若先倾听并得到“左侧有声”，用正确报告和错误报告的概率更新左侧危险概率，得到

$$b_1(L) = \frac{0.95(1/2)}{0.95(1/2) + 0.05(1/2)} = 0.95.$$

按更新后的信念，开右门的期望奖励为 $0.95(10) + 0.05(-100) = 4.5$，开左门为 $0.95(-100) + 0.05(10) = -94.5$；再次倾听只能得 -1，之后已无动作可用，因此在这三个动作中应开右门。若听见右侧，按对称计算应开左门。两种反馈各以 $1/2$ 发生，将各自的最优开门价值加权、折扣，再扣除倾听成本，初始倾听价值为

$$Q_0(b_0, \text{倾听}) = -1 + 0.9\big[(1/2)4.5 + (1/2)4.5\big] = 3.05.$$

在此两步设定下，先倾听再按反馈开门的期望回报为 3.05，高于直接开门的 -45。

图 4.4 显示了按反馈分开的动作比较。若固定同一个开门时刻，并把信号设为免费，最优开门收益的期望增量为 $4.5 - (-45) = 49.5$；实际两步方案还包含倾听成本与后续折扣，不能直接使用这个增量。模型和听觉准确率虽然已知，当前危险位置仍未知，所以倾听可能有用。剩余时间不足、先验已很确定或探测成本过高时，获得信息的收益可能不足以支付代价，直接开门反而更合适。

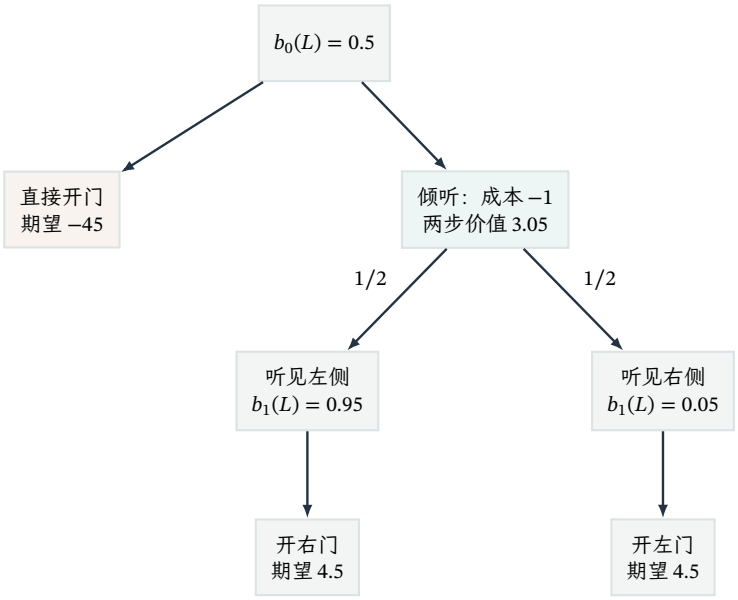


图 4.4 教学 Tiger 的两步决策树。$b(L)$ 是左门后有危险的概率。倾听反馈各以 1/2 发生，随后按新信念选择安全概率较高的门。末端标注条件期望开门奖励，根节点的 3.05 则计入倾听成本和折扣。

若只保留先验概率最大的状态，平局时任取一侧为危险，再照完全可观测解打开另一侧，预测奖励会是 10，真实期望却是 −45。这不只是平局处理的问题。将先验改为 $b_0(L) = 0.6$，点估计仍直接开右门，但真实期望为 $0.6(10) + 0.4(-100) = -34$；按 0.95 准确率计算两个倾听分支，先听再开的价值仍是 3.05。被删除的另一侧概率影响了信息是否值得获取，也就影响了当前动作。

信念足以支持最优控制，不意味着信念空间规划便宜。有限状态控制器用有限记忆节点规定动作分布和反馈后的跳转，限制了能实现的历史策略。点基值迭代保留信念的概率含义，仅在选定信念上近似价值备份。两者分别近似策略记忆和价值函数，不能混作同一种压缩；点基方法中采样了哪些信念，还会影响规划质量[6]。

在特定控制问题中，估计与控制确实可以分开。线性、高斯、模型已知且没有额外约束的二次成本控制满足相应条件时，LQG 分离原则允许把 Kalman 估计的状态均值交给线性最优反馈控制器。噪声和观测机制还须与动作无关；无限时域稳定解另需可稳定性、可检测性等条件。动作若能改变观测质量，或额外奖励透露了新的状态信息，就不能直接沿用该结论。Tiger 中的倾听恰好改变信息获取，因此一般 POMDP 没有先独立估计、再按已知状态控制的普遍保证。

模型未知时，可以把学习到的 $\boldsymbol{z}_t$ 接入第 3 章的方法。循环价值学习用它构造自举目标，循环行动者—评论家用它计算动作分布和优势，潜在模型则在该表示上学习转移与奖励，用于规划或想象轨迹。这些方法学习表

[6] J. Pineau, G. Gordon, S. Thrun, *Point-Based Value Iteration: An Anytime Algorithm for POMDPs* In Proceedings of the 18th International Joint Conference on Artificial Intelligence, 2003, pp. 1025–1030

示、价值或动力学，但还须检查表示是否能判断未实际执行的其他动作会怎样，即是否保留了反事实动作所需的信息。

4.2.5 近似决策状态的误差与计算边界

选择历史表示时，除网络参数外，还要计算保存历史、更新表示和随后规划的成本。表 4.4 按 $n = |\mathcal{S}|$、历史长度 t、窗口长度 L、单步输入维度 d、循环隐藏维度 m 和控制器节点数 k 列出直接实现的复杂度。这些是表中指定计算方式的成本，不是对全部模型的复杂度断言。

表示	历史范围与存储	一次更新代价	决策或规划空间	充分性依据
完整历史	全部；$O(td)$	追加记录 $O(d)$；重新读取至少随 t 增长	分支随时域增长的历史树	不主动丢弃已记录信息
精确信念	历史递推压缩；$O(n)$	稠密有限核 $O(n^2)$	$n-1$ 维单纯形；有限层可达点也可指数增长	已知正确模型下的充分性定理
有限窗口	最近 L 步；$O(Ld)$	缓冲追加 $O(d)$，编码另计	窗口输入；未必马尔可夫	需证明任务只依赖该窗口
有限状态控制器	当前节点 $O(1)$；节点表另计	表查找可为 $O(1)$	k 个记忆节点上的策略	策略类限制；一般非充分
学习型记忆	循环 $O(m)$；注意力缓存随 L 增长	稠密循环 $O(m^2+md)$；标准全窗口注意力 $O(L^2m+Lm^2)$	学习表示上的价值或策略	任务与模型假设，加独立验证

表 4.4 信息表示的成本与依据。注意力复杂度按宽度 m 的一层完整窗口计算，增量缓存可改变单步成本；有限状态控制器若按节点与反馈跳转，跳转表需 $O(k^2|\mathcal{Y}|)$ 存储，若另依赖实际动作，还需乘 $|\mathcal{A}|$。存在充分统计量不等于易于规划。

例如，GTrXL 中的门控与残差调整主要帮助训练保持稳定，注意力缓存和计算仍随实际保留的序列长度变化。能否较顺利地训练，与学到的表示能否充当精确决策状态，需要分别核查[7]。

要理解压缩怎样影响动作，可以沿表示、初始化、模型和求解逐一追踪。两个历史若被编码为同一 $\boldsymbol{z}$，却在同一动作下具有不同的反馈分布或价值，单凭 $\boldsymbol{z}$ 就无法区分它们；增加训练轮数不能恢复这种表示遗漏。表示本来能保存提示，却在每个重放片段开始被清零，则是初始化错误。联合核估计不准和正确目标下优化尚未收敛，又是不同误差，各自需要对应的修正。

若要把这些误差转换为动作损失，就需要对动作价值的误差作出明确假设。固定历史 h，在同一允许动作集上比较真实最优继续价值和近似值；假设各动作都有 $|\widehat{Q}(h,a)-Q^*(h,a)|\le\delta$。分别按近似值和真实值选取最大化动作 $\hat{a}\in\arg\max_a \widehat{Q}(h,a)$、$a^*\in\arg\max_a Q^*(h,a)$；插入这两个动作的近似价值，真实损失满足

$$Q^*(h,a^*)-Q^*(h,\hat{a})\le[Q^*(h,a^*)-\widehat{Q}(h,a^*)]+[\widehat{Q}(h,\hat{a})-Q^*(h,\hat{a})]\le 2\delta.$$

[7] E. Parisotto, F. Song, J. Rae, R. Pascanu, C. Gulcehre, S. Jayakumar, M. Jaderberg, R. L. Kaufman, A. Clark, S. Noury, M. Botvinick, N. Heess, R. Hadsell, *Stabilizing Transformers for Reinforcement Learning* In Proceedings of the 37th International Conference on Machine Learning, 2020, pp. 7487–7498

中间省去的差为非正，因为 $\hat{a}$ 最大化近似值，即 $\widehat{Q}(h, a^*) \le \widehat{Q}(h, \hat{a})$。这一界要求逐动作误差受控，平均重建损失没有直接提供该条件；没有表示误差到价值误差的论证，就不能把训练损失当作 δ。

例 4.2 还可以直接检验重建与控制的区别。沿用不折扣成功奖励，两个记忆节点分别保存左右提示即可达到期望值 1，丢弃提示则至多达到 1/2。即便窗口内每帧都完美重建，1/2 的控制差距仍在。若奖励后来改为依赖另一条早期线索，仅保存 c 又可能不足，当前任务充分性不能扩展为对所有奖励目标充分。第 3 章讨论更一般的样本复杂度与函数类条件；本例先表明，表示丢掉的信息不能靠更多样本或更充分的优化补回。

4.3 固定经验下的策略评价与选择

4.3.1 固定经验与行为策略

下面暂时恢复完全可观测条件：每条记录都有完整状态，但学习者不能再到环境中试验。要用这些记录评价另一策略，先要弄清动作由谁、按什么概率选出。同一份状态动作表可能来自固定策略、多个策略的混合或持续更新的控制器；收集方式不同，概率校正和误差估计所用的条件也不同。

定义 4.9　行为策略与目标策略　沿用前文的行为策略 μ 与目标策略 π：前者生成日志动作，后者是待评价或部署的决策规律。将有限时域中收集的 n 个回合写为

$$\mathcal{D} = \{\tau_i\}_{i=1}^{n}, \qquad \tau_i = (s_{i,0}, a_{i,0}, r_{i,0}, \dots, s_{i,H}).$$

本节采用有限时域价值 $J_H(\pi) = \mathbb{E}_\pi[\sum_{t=0}^{H-1} \gamma^t r_t]$。若回合提前终止，则以吸收状态和零奖励补到 H。J_H 只累计有限时域，不等于无限时域的 J；后文切换目标时将另作说明。

单一马尔可夫行为策略可逐步记录 $\mu(a_t \mid s_t)$。多个子策略混合时，必须区别抽取时机：每步重新按已知概率选择子策略，可以用该步混合权重加权动作概率；回合开始只抽一次，则历史会改变对所选子策略的后验，通常不能一直使用固定混合权重。后一种收集方式需要保存策略身份及相应概率并作适当的条件采样分析，或记录真正的 $\mu_t(a_t \mid h_t)$；这里的历史包含行动前记录的完整状态、动作和奖励。身份字段说明了收集机制，却不能补齐某个条件层中缺失的目标动作。若策略随收集过程自适应更新，还须保存版本和选择机制。

这些动作概率最好来自当时实际使用的随机化机制。机制记录正确时，概率是已知量；事后拟合的 $\hat{\mu}$ 则含有模型误差。确定性收集者没有尝试的

动作，即使密度网络给出非零概率，也仍没有行为支持。表 4.5 说明哪些日志字段支撑评价中的具体计算。

字段	支撑的计算与省略后的风险
状态、动作、奖励、下一状态	构造回报、Bellman 目标及目标策略动作概率
真终止标记	真正终止后不再自举；终止奖励仍记在 r_t
时间截断标记	区分任务结束与记录停止；持续任务截断处通常仍需继续价值
回合标识与时刻	恢复轨迹概率比、记忆重置和回合级划分
行为概率及策略版本	确定动作选择机制，区分已知概率与估计概率
初始条件、任务与目标	说明评价的 ρ_0、奖励定义及任务分布是否匹配

表 4.5 完整状态日志仍需要采样元数据。有限时域的真正 H 步终止与持续任务在 H 处被时间截断，具有不同的自举目标。

恢复回合边界后，还要确定统计重复的单位。独立收集的 n 个回合可以作为独立评价单位，回合内相邻转移却不能直接当作独立重复。只有一条相关长轨迹时，分块估计或相关数据推断需要混合性等条件，即随时间间隔增加，相关性受到相应控制。把相邻转移随机拆到训练与测试中，可能泄露轨迹信息，也会高估独立样本数。

D4RL 包含不同质量、收集者及混合任务的数据，因此报告时要保留具体版本、奖励定义和归一化分数的参照；仅称“专家混合数据”还不能确定实验输入[8]。除了数据组成，RL Unplugged 还区分任务域与选模协议。调参是否使用在线策略测试尤其需要声明：如果依据真实环境分数选择超参数，整个选模过程就已超出纯固定经验评价[9]。

Minari 按回合提供数据与元数据接口，但具体数据集的终止、截断、环境版本和收集者说明仍须核对，存储格式并不保证行为概率可得[10]。对于 OGBench 这样的离线目标条件强化学习基准，还要报告无奖励数据的组成、目标怎样选择、奖励怎样重标记以及测试目标协议。目标条件改变后，成功率不能直接横比。OGBench 已有 ICLR 2025 正式版本；这里用它说明协议需包含哪些内容，不据其分数判断方法普遍优劣[11]。

4.3.2 策略价值的可识别性与覆盖条件

固定日志可以交给多个候选策略评价，但每个候选会使用不同的状态动作。比较分数之前，先假设能够无限重复原收集方式，检查是否仍会有不同环境给出同样日志、却赋予候选不同价值。这是**可识别性**（identifiability）问题：可观察的数据规律能否唯一确定目标量。若不能，增加同类样本也无法只靠估计精度解决。

[8] J. Fu, A. Kumar, O. Nachum, G. Tucker, S. Levine, *D4RL: Datasets for Deep Data-Driven Reinforcement Learning* In arXiv preprint arXiv:2004.07219, 2020

[9] C. Gulcehre, Z. Wang, A. Novikov, T. L. Paine, S. G. Colmenarejo, K. Zolna, R. Agarwal, J. Merel, D. Mankowitz, C. Paduraru, G. Dulac-Arnold, J. Li, M. Norouzi, M. Hoffman, O. Nachum, G. Tucker, N. Heess, N. de Freitas, *RL Unplugged: A Suite of Benchmarks for Offline Reinforcement Learning* In Advances in Neural Information Processing Systems, 2020

[10] Farama Foundation, *Minari: Dataset Standards and Episode Data*, URL: https://minari.farama.org/ (visited on 10/04/2026)

[11] S. Park, K. Frans, B. Eysenbach, S. Levine, *OGBench: Benchmarking Offline Goal-Conditioned RL* In International Conference on Learning Representations, 2025

定义 4.10 策略价值可识别 策略价值可识别性以给定的数据生成协议、可观察字段、环境结构假设、初始分布和目标策略为条件。若所有产生相同可观测数据总体分布的允许环境都给出相同目标策略价值，则该价值可识别。这是总体分布的性质，不说明有限样本估计已经准确。

定理 4.11 固定经验不能识别未覆盖动作的价值 对单状态、单步、两个动作的任务，若日志行为只执行其中一个动作，且没有将两动作奖励联系起来的结构假设，则另一动作的价值及其相对行为策略的优劣一般不可识别。

证明 用两个仅在未见动作上不同的环境检验定义。唯一非终止状态为 s，执行 a_0 或 a_1 后均终止。在 M_+ 与 M_- 中，a_0 的奖励都为 0，a_1 的奖励分别为 $+1$ 和 -1；两环境的行为均为 $\mu(a_0 \mid s) = 1$。

无论日志多大，其中只有 $(s, a_0, 0, s_{\text{term}})$，所以可观测分布完全相同。但目标 $\pi(a_1 \mid s) = 1$ 的价值分别是 $+1$ 和 -1，行为基线价值均为 0。只使用日志的程序收到相同输入，其输出分布也相同，无法在两个环境中都正确确定目标价值或排序。因此，按定义，这两项结论都不可识别。 ■

给 a_1 产生数值预测还不够。神经网络可以外推，结构化动力学也可以将 a_0 的信息迁移到 a_1，但需要可核验的正确性假设说明两动作怎样联系，才可能排除上述一个环境。网络能表达这种联系，不表示日志已经证明它成立。

为检查哪些候选避开了这一缺口，可以比较候选诱导的轨迹分布和行为分布。候选可能使用而行为绝不产生的轨迹，无法通过日志重加权补出；即使没有这种绝对缺口，也要考察候选是否把大量概率放在日志极少涉及的区域。

定义 4.12 支持、集中程度与部分覆盖 目标轨迹分布 p_π 相对行为轨迹分布 p_μ**绝对连续**，记 $p_\pi \ll p_\mu$，表示行为概率为 0 的任何轨迹事件也具有零目标概率。在共同环境核的有限模型中，目标可达历史上的每个目标动作都须有行为支持。

若将评价改为无限时域折扣占用而非有限整条轨迹，则用前文归一化的 $d^\pi(s, a)$ 表示目标访问概率，以 $\nu(s, a)$ 表示数据转移的归一化采样分布。集中程度系数衡量目标访问相对数据采样可能集中到多

大程度，用本质上确界记录占用比的上界而非平均大小，即取遍 ν 支持中的状态动作、忽略 ν 零测集。其定义为

$$C_\pi = \operatorname*{ess\,sup}_{(s,a)\sim\nu} \frac{d^\pi(s,a)}{\nu(s,a)},$$

并要求 $d^\pi \ll \nu$。部分覆盖表示上述条件仅在某些策略或状态动作区域成立。可达性只说明某动作序列在环境中可能到达一处，不说明收集者赋予它正概率。

非零支持排除了绝对缺口，却没有控制有限样本中的困难。目标经常使用的动作若只有 10^{-6} 行为概率，小日志很可能一次都未收集到；即使出现，概率校正也可能赋予很大权重。估计器不同，所需控制量可能是逐时占用比、轨迹密度比或其矩，不能把 C_π 作为所有分析的同一个条件。

希望得到的结论	需要支持的行为范围	额外结构与不能省略的检查
给定策略评价	该策略的相关轨迹或占用	正确奖励、初始分布与行为机制；模型外推须有依据
候选排序	候选共同模型下的性能差	不一定要分别点识别两个价值；差的符号必须有证据
相对基线改进	候选与基线的比较行为	选择后仍有效的误差控制；缺数据处可限制回到基线
策略类中最优	足以排除所有有竞争力的替代行为	通常需更广覆盖或更强结构；高回报轨迹本身不够

表 4.6 结论越强，通常需要检查越多行为。结构假设可改变所需覆盖，但必须说明它如何排除与日志一致的不同环境。

表 4.6 将覆盖要求对应到结论强度。日志可能完整显示一条奖励为 10 的路径，却没尝试岔路处的另一动作；后者通向奖励 11 或 -100，都可与日志相容。已观察路径可行有数据依据，路径最优或偏离它的策略更好却没有同样依据。因此，少量高回报轨迹不能替代备选行为的覆盖。

4.3.3 离线策略价值的估计

价值可识别后，仍要由有限日志计算估计。**离策略评价**（off-policy evaluation, OPE）用其他行为策略收集的数据估计目标策略价值；这里还限制为不能新增交互。先固定待评价的 π，假设回合独立、初始分布及环境核共同、行为动作概率已知，且 $p_\pi \ll p_\mu$。沿用定理3.6的矩条件，目标下每步奖励绝对可积。为确定日志应怎样加权，先按生成顺序展开有限时域马尔可夫策略的轨迹密度：

$$p_\pi(\tau) = \rho_0(s_0) \prod_{t=0}^{H-1} \pi_t(a_t \mid s_t) p(s_{t+1}, r_t \mid s_t, a_t).$$

将 π 换为 μ 得到行为密度，再计算目标密度除以行为密度。共同初始项和环境项约去，只需将沿途的目标动作概率除以行为概率并相乘：

$$w_{i,0:t} = \prod_{k=0}^{t} \frac{\pi_k(a_{i,k} \mid s_{i,k})}{\mu_k(a_{i,k} \mid s_{i,k})}. \tag{4.5}$$

这一比率把行为日志中的期望转换为目标策略下的期望，复用了第 3 章的换测度关系。初始分布若改变却未校正，或行为实际使用了未记录信息，便不能按上式消去相应因子。

令 $G_i = \sum_{t=0}^{H-1} \gamma^t r_{i,t}$。可以将每条完整回报乘以轨迹比，再对独立回合取平均；也可以对每个奖励只校正此前的动作，随后累计和平均。普通轨迹重要性采样与逐决策形式分别为

$$\begin{aligned} \widehat{J}_{\mathrm{IS}} &= \frac{1}{n} \sum_{i} w_{i,0:H-1} G_i, \\ \widehat{J}_{\mathrm{PDIS}} &= \frac{1}{n} \sum_{i} \sum_{t=0}^{H-1} \gamma^t w_{i,0:t} r_{i,t}. \end{aligned} \tag{4.6}$$

奖励 r_t 在 a_t 执行后产生，校正其分布须包括 a_t，无需包括之后的动作。截到该奖励的前缀密度比正是 $w_{i,0:t}$，由此得到逐决策形式；不必另外要求目标概率为 0 的行为历史上后续权重条件均值为 1。概率正确、支持和上述矩条件成立时，两式都无偏，但相乘的权重可能随时域快速增大。

示例 4.13　三条两步轨迹的概率校正　为核算概率校正，给定一个教学 MDP：从 s_0 出发，任意动作都到 s_1，再行动一步终止。两个时刻均可选 A, B，奖励为 $r_0(A) = 1$、$r_0(B) = 0$、$r_1(A) = 2$、$r_1(B) = 0$，奖励与转移都确定，$\gamma = 0.9$。行为每步均匀选择，目标每步以 $3/4$ 概率选择 A。对每步目标奖励取期望再折扣，真实价值为 $J_2(\pi) = 3/4 + 0.9(2 \times 3/4) = 2.1$。

假设独立收集到 AA, BA, BB 三条轨迹。按上述动作概率计算前缀比和回报，得到

轨迹	G_i	$w_{i,0:0}$	$w_{i,0:1}$	$\sum_t \gamma^t w_{i,0:t} r_{i,t}$
AA	2.8	1.5	2.25	5.55
BA	1.8	0.5	0.75	1.35
BB	0	0.5	0.25	0

先乘完整轨迹比再平均，普通 IS 为 $(2.25 \times 2.8 + 0.75 \times 1.8)/3 = 2.55$；逐奖励使用前缀比，逐决策 IS 为 $(5.55 + 1.35)/3 = 2.3$。本批样本的两个估计都偏离 2.1；无偏性说的是反复收集整批日志后的估计期望，不保证每批数值准确。

轨迹权重过大时，可以改动汇总方式以减轻少数样本的影响，但也会改变统计性质。自归一化估计用 $\widehat{J}_{\mathrm{SN}}=\sum_i w_iG_i/\sum_i w_i$，用总权重而非 n 归一化，要求分母非零；截断估计则预先选择正阈值 c，限制每条权重不超过 c：$\widehat{J}_{\mathrm{clip}}=n^{-1}\sum_i \min(w_i,c)G_i$。例 4.13 取 $w_i=w_{i,0:1}$ 时，自归一化结果为 $7.65/3.25\approx 2.3538$；取 $c=1$ 的未归一化截断结果为 $(2.8+0.75\times 1.8)/3\approx 1.3833$。前者使用随机分母，后者修改精确换测度权重，一般都会引入有限样本偏差。以拟合行为概率替代已知概率，也改变无偏性条件。有效样本量诊断 $(\sum_i w_i)^2/\sum_i w_i^2$ 检查总权重是否主要由少数轨迹承担，却不检验奖励或行为模型是否正确，因而不能证明价值估计正确。

若日志能支持目标继续动作，也可以不乘整条轨迹的概率比，改为拟合目标策略的 Bellman 关系。**拟合 Q 评价**（fitted Q evaluation, FQE）固定 π，用记录奖励与下一步目标价值构造回归目标，因此只评价、不取动作最大值。有限时域中令 $\widehat{Q}_H=0$，从末步向前更新。时刻 t 在允许函数类 $\mathcal{F}_t$ 中选取 f，使数据上的平方残差最小；下一动作按固定 π_{t+1} 取期望：

$$\widehat{Q}_t\in\arg\min_{f\in\mathcal{F}_t}\sum_i\left[f(s_{i,t},a_{i,t})-r_{i,t}-\gamma\mathbb{E}_{a'\sim\pi_{t+1}(\cdot|s_{i,t+1})}\widehat{Q}_{t+1}(s_{i,t+1},a')\right]^2. \tag{4.7}$$

其中 $\mathcal{F}_t$ 限定时刻 t 可拟合的价值函数。末步 $t=H-1$ 的继续价值直接为 0，无需定义终点策略。若改为无限折扣任务，则用时间不变的函数类反复回归，以上一轮 $\widehat{Q}^{(k)}$ 构造目标，得到 $\widehat{Q}^{(k+1)}$。两种形式都在真终止处屏蔽后续项。回归后，对初始状态及目标初始动作取期望，有限时域得到 $\widehat{J}_H(\pi)=\mathbb{E}_{s_0\sim\rho_0,a_0\sim\pi_0}\widehat{Q}_0(s_0,a_0)$；初始分布未知时，需要相应初态样本。每轮拟合要扫描或采样数据、计算目标动作期望并求解回归，非线性函数类还会产生优化误差。小训练平方误差仅说明数据上的拟合，有限样本价值界另需函数类、Bellman 逼近和覆盖条件[12]。

[12] H. Le, C. Voloshin, Y. Yue, *Batch Policy Learning under Constraints* In Proceedings of the 36th International Conference on Machine Learning, 2019, pp. 3703–3712

示例 4.14　在同一日志上完成 FQE 与 DR　在例 4.13 的同三条轨迹上，每个时刻使用独立价值表。先拟合末步奖励，得到 $\widehat{Q}_1(s_1,A)=2$、$\widehat{Q}_1(s_1,B)=0$，故 $\widehat{V}_1(s_1)=0.75(2)+0.25(0)=1.5$。再将这个目标继续价值传回初始步，两个回归目标为

$$\widehat{Q}_0(s_0,A)=1+0.9(1.5)=2.35,\qquad \widehat{Q}_0(s_0,B)=0+0.9(1.5)=1.35.$$

按目标的初始动作概率加权，得到 $\widehat{J}_{\mathrm{FQE}}=0.75(2.35)+0.25(1.35)=2.1$。本次结果精确，因为所需状态动作全已出现且后果确定；不能由此认为三条轨迹总是够用。若两时刻从零同时更新，第一轮只能拟合即时奖励，第二轮才会把 1.5 的继续价值传回初态。

再将辅助预测与概率加权残差合用，观察预测不准时怎样校正。这种方法称为**双重稳健估计**（doubly robust estimation, DR），即权重或

辅助价值有一侧正确时，在相应条件下仍可得到正确均值；具体条件将在一般公式后说明。为核算残差，事先给定不准确的辅助价值：$\widehat{Q}_1(A)=1$、$\widehat{Q}_1(B)=0$，$\widehat{Q}_0(A)=1.5$、$\widehat{Q}_0(B)=0.5$。对目标动作加权，得 $\widehat{V}_1=0.75$、$\widehat{V}_0=1.25$。用实际奖励加预测继续价值减去当前预测，初始步残差 $r_0+0.9\widehat{V}_1-\widehat{Q}_0$ 对两动作都为 0.175，末步对 A 为 1、对 B 为 0。将这些残差按前缀比校正，加到初始预测上，三条轨迹在下面双重稳健公式中的贡献为

$$D_{AA}=1.25+1.5(0.175)+0.9(2.25)=3.5375,$$
$$D_{BA}=1.25+0.5(0.175)+0.9(0.75)=2.0125,$$
$$D_{BB}=1.25+0.5(0.175)=1.3375.$$

平均贡献为 2.2958，尚有样本误差；若使用上面精确的 FQE 辅助值，各步残差均为 0，每条轨迹都贡献 2.1。

上例的 DR 使用有限时域逐决策形式，从预测初始价值出发，用实际反馈相对预测的 Bellman 残差修正。先按固定策略动作取期望，构造辅助 $\widehat{V}_t(s)=\mathbb{E}_{a\sim\pi_t}\widehat{Q}_t(s,a)$，并令 $\widehat{V}_H=0$；每个残差用截至该反馈的概率比转到目标分布，折扣累加后再平均回合贡献：

$$\widehat{J}_{\mathrm{DR}}=\frac{1}{n}\sum_i\left[\widehat{V}_0(s_{i,0})+\sum_{t=0}^{H-1}\gamma^t w_{i,0:t}(r_{i,t}+\gamma\widehat{V}_{t+1}(s_{i,t+1})-\widehat{Q}_t(s_{i,t},a_{i,t}))\right]. \tag{4.8}$$

“双重稳健”指权重或辅助价值有一侧正确时，在相应条件下仍可得到正确均值。为陈述精确无偏性，辅助函数须由独立训练数据拟合，或交叉拟合，使评价轨迹不参与自己的辅助训练。权重正确时，残差转到目标分布，$\widehat{V}$ 和 $\widehat{Q}$ 项沿时间望远镜消去，留下 $J_H(\pi)$，辅助值有误也不影响等式。辅助值全部满足 $\widehat{Q}_t=Q_t^\pi$ 时，给定行动前历史与当前动作，残差条件均值为 0，初始价值期望则正确；有限且在反馈前确定的错误行为权重也不改变均值。两侧都错便没有这种保证，任一侧正确也不保证方差小[13]。

不使用行为概率的 FQE 仍需要覆盖。若上例在 s_1 只记录 B，目标却选择 A，$\widehat{Q}_1(s_1,A)$ 便无直接监督；其偏差 e 会以 $\gamma\pi(A\mid s_1)e$ 进入初态目标，即使初态数据拟合完全正确也如此。模型评价遇到同样缺口时，传播的是奖励与转移预测误差。

轨迹比之外，还可以直接校正状态动作的分布。这里从有限时域切换到无限折扣、时间不变 MDP，使用前文归一化的 d^π。DICE 类方法不必显式拟合 μ，而由占用流量平衡学习 $w(s,a)=d^\pi(s,a)/\nu(s,a)$；DualDICE 通过对偶优化求解这类分布校正问题[14]。为确定比率，要求它对适当测试函数

f 恢复目标占用的流量关系：当前测试值减去折扣后的下一测试值，其加权期望等于初始输入质量。得到正确比率后再校正奖励期望：

$$\mathbb{E}_{\nu,P,\pi}\big[w(s,a)\{f(s,a)-\gamma f(s',a')\}\big]=(1-\gamma)\mathbb{E}_{\rho_0,\pi}f(s_0,a_0),$$
$$J(\pi)=\frac{1}{1-\gamma}\mathbb{E}_{\nu}[w(s,a)R(s,a)]. \tag{4.9}$$

式中 $a'\sim\pi(\cdot\mid s')$，条件正确的奖励样本可以替代奖励均值。d^π 与 ν 均归一化，而 J 是未归一化折扣回报，必须保留 $(1-\gamma)^{-1}$。占用比校正仍要求目标受日志支持；省略行为拟合不会使支持外的价值可识别。

估计路线	必需信息	拟合对象	关键覆盖要求	主要误差
IS	轨迹、目标与行为概率	可不拟合模型	目标轨迹相对行为绝对连续	乘积权重方差；概率估计偏差
模型评价	转移、奖励及初始条件	$\widehat{P},\widehat{R}$	目标行为后果有支持或正确结构	模型误设、长滚动误差
FQE	转移、固定 π、初态	Q^π	目标继续动作及状态可被评价	回归、投影、自举传播
本节 DR	IS 字段和辅助价值	$\widehat{Q},\widehat{V}$	仍需目标支持；辅助拟合与评价分离	双方错误的交互、权重方差
DualDICE	转移分布、初态、π	占用比及对偶函数	$d^\pi\ll\nu$ 与可控比值	比率函数逼近、优化与采样误差

表 4.7 固定策略的评价路线。表中列出的是各具体形式的条件，不将某一 DR 或 DICE 变种的结论推广到全部同名方法。

表 4.7 按同一固定策略任务汇总了所需信息和误差来源。评价器首先要与日志字段、支持条件相容，之后才比较方差、拟合成本和偏差控制；估计分数较高本身不是选择它的理由。

4.3.4 候选策略的比较与选择

此前的估计针对固定 π；若在同一日志上评价许多候选，再挑分数最高者，评价对象便由数据选择了。即便每个预固定候选都无偏，最大分数也容易选中正向噪声。候选和查询次数越多，直接报告被选中的最大值越可能乐观。

为控制选择影响，可以分清训练、选择与最终报告的数据职责。训练集产生候选和辅助模型，选择集用于调参或保留候选，最终评价集仅承担预先确定的报告。样本少时可采用严谨交叉拟合或统一误差控制；反复查看过的最终集已经参与选择，不能再称为未使用测试集。所有划分仍只重用原日志，不能创造缺失支持。

对于预先固定的两个候选，可以复用同一评价轨迹计算性能差。令 $Z_i(\pi)$ 为 IS 或满足相应条件的 DR 轨迹贡献，先在每个回合算 π_1 贡献减去 π_2 贡献，再平均：

$$\widehat{\Delta}=\frac{1}{n}\sum_i[Z_i(\pi_1)-Z_i(\pi_2)]. \tag{4.10}$$

这里估计的是 π_1 价值减去 π_2 价值，真实差为正表示 π_1 回报更高；有限样本的估计正值还要结合误差判断。固定候选与辅助模型、使用独立同分布评价回合且贡献的二阶矩有限时，为判断差的估计波动，将相减贡献的方差展开为

$$\operatorname{Var}(\widehat{\Delta}) = \frac{1}{n}\left[\operatorname{Var}(Z(\pi_1)) + \operatorname{Var}(Z(\pi_2)) - 2\operatorname{Cov}(Z(\pi_1), Z(\pi_2))\right].$$

共享轨迹可能使两个估计同向波动，正协方差会减小差的方差，负协方差则增大它。只看两个单独价值区间是否重叠，会遗漏比较所需的相关信息。

示例 4.15　价值区间重叠仍可比较性能差　构造两项价值估计 5 和 4，各自标准误为 1，两均值估计的协方差为 0.98。相减得到性能差 1，按方差公式计算标准误为 $\sqrt{1+1-2(0.98)} = 0.2$。另假设正态近似适用，边际 95% 区间为 $[3.04, 6.96]$ 与 $[2.04, 5.96]$，高度重叠；配对差的 95% 区间为 $[0.608, 1.392]$，却不包含 0。这些统计量用于教学，不是实际运行实验所得。

图 4.5 将单独价值与配对差的区间分开。此处价值在总体上可确定，区间来自有限样本误差；第 4.6.4 节将改变这一条件，即使总体分布已知也可能存在多个相容价值。那里仍需比较共同模型下的差，但模型歧义与此处的采样波动是两类不确定性。

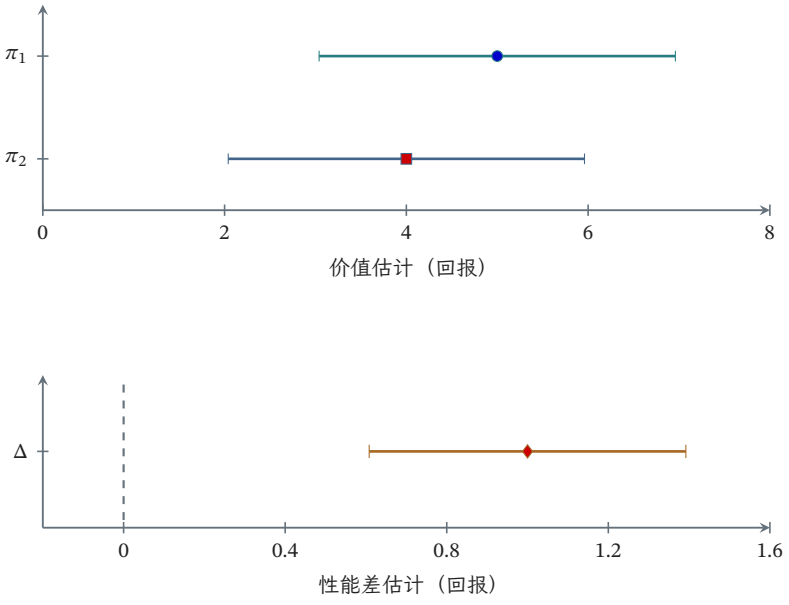


图 4.5　例 4.15 的教学区间。上组为两个价值的边际 95% 正态近似区间，下组为共享轨迹计算的性能差区间；两组横轴各自标明量纲为回报。区间重叠与差是否包含 0 并非同一个判断。

比较报告须列明候选数、产生候选所用数据、重复查询次数、置信水平和多重比较处理。候选集预先固定且有限时，可以分配各候选的失败概率，用并集界控制所有区间共同有效的事件；自适应增加候选不能直接沿用单候选区间。证据不足以排序时，就保留尚未排除的候选或报告无法排序。更多小数位不会增加证据。

4.4 固定经验下的策略学习与改进

4.4.1 策略学习的目标与数据边界

评价固定策略只检查指定行为，学习则要由日志生成新的候选。可以先以记录行为为拟合目标。**行为克隆**（behavioral cloning, BC）就是让策略在日志状态上给记录动作较高概率；在参数化策略类中，通过降低数据动作的平均负对数似然拟合参数：$\min_{\phi} \mathbb{E}_{\mathcal{D}}[-\log \pi_{\phi}(a \mid s)]$。这一目标不使用奖励来重新分配概率。离线强化学习希望利用同一日志中的奖励选择行为，因此还要规定改进的比较基准。

拟合行为检查策略是否复现数据动作，提高估计回报检查学习目标是否上升。相对基线改进比较 $J(\pi)$ 与 $J(\pi_b)$，逼近最优则比较候选与允许策略类中最好的真实价值。后三者没有自动联系：优化器可能提高估计目标，却因查询数据外动作而利用模型错误，降低真实回报。

> **示例 4.16　一次贪心更新利用了外推错误**　在单步教学任务中，日志只记录奖励为 1 的 a_0；未记录的 a_1 真实奖励为 -10。网络预测 $\widehat{Q}(s,a_0)=1$、$\widehat{Q}(s,a_1)=5$，数据动作平方误差为 0。按两个动作中的最大预测值作一次贪心更新，会选中 a_1：估计回报从 1 升为 5，真实回报从 1 降为 -10。反复拟合原日志中的 a_0 仍不会提供 a_1 的正确后果。

图 4.6 把这类外推分成三个入口：策略生成新动作，价值备份查询新动作，规划器生成未观测状态动作。后续方法按限制这三个位置展开，也可组合使用。比较时保持数据与评价协议相同，说明优化对象、部署动作怎样产生以及额外假设；采用 Transformer、扩散或流模型，并不单独说明策略是否改进。

4.4.2 行为数据约束下的策略学习

在例 4.16 中，问题由策略选择未见动作触发，可以先约束候选偏离记录行为的程度。以下保持完全可观测与固定 $\mathcal{D}$，将价值目标改为无限折扣回报。TD3+BC 沿用 TD3 的双评论家、目标网络和延迟行动者更新，在确定

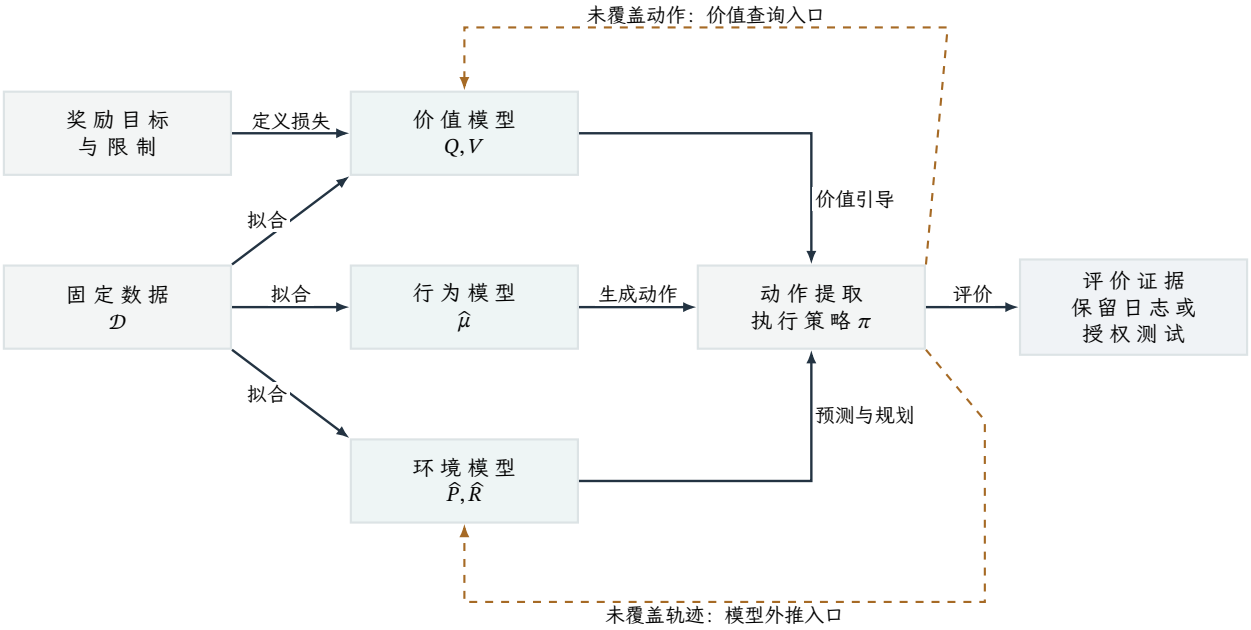


图 4.6 固定数据上的学习与评价。实线分别标注拟合、生成动作及评价，虚线标出外推可能进入的查询。行为约束限制动作来源，悲观价值限制对未支持动作的乐观估计，模型约束限制规划范围；任何一条学习路径仍需独立的评价证据。

性行动者 $f_{\phi}(s)$ 的参数类中比较预测价值与动作平方偏差。对日志状态动作取平均，最大化价值减去偏差：

$$\max_{\phi} \mathbb{E}_{(s,a)\sim\mathcal{D}}\left[\lambda Q_{\theta}(s, f_{\phi}(s)) - \|f_{\phi}(s) - a\|_2^2\right]. \tag{4.11}$$

动作是向量时，范数比较各动作坐标，此处沿用动作符号 a。为调节价值项与距离项的相对尺度，在含 N 条记录的一批数据上常取 $\lambda = \alpha/(\frac{1}{N}\sum_i |Q_{\theta}(s_i, a_i)|)$，其中 α 控制相对强度，行动者更新时固定 λ，分母为 0 时实现须有非零保护。按链式法则对行动者参数求梯度，可以看到两项各自推动动作的方向：

$$\mathbb{E}_{\mathcal{D}}\left[(\nabla_{\phi} f_{\phi}(s))^{\top}\{\lambda \nabla_a Q_{\theta}(s,a)|_{a=f_{\phi}(s)} - 2(f_{\phi}(s) - a)\}\right].$$

价值梯度推动动作朝预测价值较高处移动，距离梯度将它拉回记录动作。约束太弱可能再次利用外推，太强则接近模仿。两项的相对作用随奖励和动作尺度改变，因此比较 α 必须同时给出归一化方式[15]。

若日志行为有多个动作模式，平方拟合可能得到模式之间数据稀少的均值动作。可以让行为模型生成不同模式，再在候选附近改进。**批量约束 Q 学习**（batch-constrained Q-learning, BCQ）以这种方式缩小价值筛选的动作范围。连续动作版本先用 (s, a) 训练条件变分自编码器：编码器生成潜变量后验，解码器 $g_{\omega}(s, \boldsymbol{z})$ 用后验样本重构动作；生成候选时改从规定先验采样，不读取待生成的数据动作。随后由 $\xi_{\phi}(s, a)$ 给每个坐标加入

[15] S. Fujimoto, S. S. Gu, *A Minimalist Approach to Offline Reinforcement Learning* In Advances in Neural Information Processing Systems, 2021

方法	行为接近度	施加位置	执行动作来源	强度与代价
BEAR	动作样本的核最大均值差异	行动者约束, 间接限制备份	训练后的随机行动者; 可对候选评分	阈值、核及拉格朗日权重; 行为模型与样本比较
BRAC	相对行为模型的 KL 等散度	策略正则, 或同时进入价值递推	正则化行动者	散度权重; 行为密度拟合误差
ReBRAC	相对数据动作的平方距离	行动者及评论家目标的独立惩罚	确定性行动者	两处惩罚系数; 数据下一动作与实现配置

表 4.8 行为正则的不同位置。表中“接近”都不表示已经获得未见动作的真实后果；实际比较还需固定动作尺度、数据与选模预算。

$[-\Phi, \Phi]$ 内的扰动，$\Phi \geq 0$，并截到合法动作域。生成 m 个候选后，仅按 Q_1 在这些修正候选中取最大值，得到执行动作：

$$a_j = g_\omega(s, \boldsymbol{z}_j), \qquad \tilde{a}_j = \mathrm{clip}_{\mathcal{A}}(a_j + \xi_{\boldsymbol{\phi}}(s, a_j)), \qquad a_{\mathrm{exec}} \in \underset{\tilde{a}_j,\, 1 \leq j \leq m}{\arg\max}\, Q_1(s, \tilde{a}_j). \tag{4.12}$$

行为生成器以动作重构误差加潜变量后验相对标准先验的 KL 项训练。评论家备份也从下一状态生成 m 个候选, 用目标网络的 $\eta \min(Q_1^-, Q_2^-) + (1-\eta)\max(Q_1^-, Q_2^-)$ 评分，其中 $\eta \in [0,1]$ 越大，越偏重两个评论家中的较小值。对候选取最高评分，构造 $r_t + \gamma$ 倍继续价值的回归目标；真终止时后续为 0。扰动网络在限幅内提高 Q_1，目标网络缓慢更新。部署实际输出式 (4.12) 选中的动作，不是行为模型。候选数 m 为正整数，增加它会增加生成与价值计算；增大 Φ 则放宽偏离日志的范围[16]。

例如,标量教学状态中的生成器给出 $-0.2, 0.1, 0.3$,扰动后为 $-0.15, 0.1, 0.25$, 对应 Q_1 评分 $0.4, 0.8, 0.6$，于是执行 0.1。这个筛选范围较小，却不说明三动作后果都已有充分记录：生成模型可能跨过数据空洞，扰动也可能越出支持。BCQ 限制的是最大化搜索范围，覆盖条件仍须检查。

其他行为正则方法也限制偏离，但度量和施加位置不同。BEAR 用最大均值差异比较行动者与行为动作样本，即比较核特征中的分布均值，约束备份尽量少查询分布外动作；距离含义取决于核、样本和阈值[17]。BRAC 比较将行为分布散度加入策略目标或价值递推的不同方式。ReBRAC 沿用 TD3+BC，在行动者与评论家目标中分别调节行为惩罚，并检查网络、批量和归一化等实现因素。表 4.8 据此对照各自限制的位置；这些改动不增加真实信息[18,19]。

还可以不用显式行为距离，改用回报条件区分日志中的动作模式。Decision Transformer 将过去状态、动作与剩余回报按因果顺序编码，以监督动作预测拟合 $\pi_{\boldsymbol{\phi}}(a_t \mid h_t, g_t)$。这里又回到有限时域，其常见条件为未折扣剩余回报 $g_t = \sum_{k=t}^{H-1} r_k$，不是默认折扣 G_t。部署由用户指定希望达到的 g_0，每步扣去实际奖励，按 $g_{t+1} = g_t - r_t$ 更新。训练中 g_t 描述已发生轨迹的结果，部署中它是目标愿望；条件相同不保证结果可实现[20]。

[16] S. Fujimoto, D. Meger, D. Precup, *Off-Policy Deep Reinforcement Learning without Exploration* In Proceedings of the 36th International Conference on Machine Learning, 2019, pp. 2052–2062

[17] A. Kumar, J. Fu, G. Tucker, S. Levine, *Stabilizing Off-Policy Q-Learning via Bootstrapping Error Reduction* In Advances in Neural Information Processing Systems, 2019

[18] Y. Wu, G. Tucker, O. Nachum, *Behavior Regularized Offline Reinforcement Learning* In arXiv preprint arXiv:1911.11361, 2019

[19] D. Tarasov, V. Kurenkov, A. Nikulin, S. Kolesnikov, *Revisiting the Minimalist Approach to Offline Reinforcement Learning* In Advances in Neural Information Processing Systems, 2023, pp. 11592–11620

[20] L. Chen, K. Lu, A. Rajeswaran, K. Lee, A. Grover, M. Laskin, P. Abbeel, A. Srinivas, I. Mordatch, *Decision Transformer: Reinforcement Learning via Sequence Modeling* In Advances in Neural Information Processing Systems, 2021

示例 4.17 回报条件不能控制外部随机结果 设单步教学任务的奖励与动作独立：公平硬币以 1/2 概率给 1，否则给 0。仅取回报 1 的轨迹训练条件动作模型，可以完全拟合成功数据；但部署持续输入目标 1，成功概率仍为 1/2。按结果条件化只排除了失败样本，并未得到能够改变成功概率的动作。

回报条件模仿由结果标签区分行为，显式距离约束则惩罚分布或动作偏离，二者目标不同。前者可以表示高回报轨迹中的动作模式，却要面对幸运随机结果、不可达目标和日志外状态。判断执行策略是否改进，仍需第 4.3 节的价值证据。

4.4.3 价值估计与策略更新中的外推控制

例 4.16 中的未见动作被高估，除了限制策略，也可以改变价值训练。**保守 Q 学习**（conservative Q-learning, CQL）对缺少数据支持的高价值增加惩罚，使策略不容易因这些预测而偏离日志[21]。这里保持无限折扣价值和固定数据，采用有限动作的一种常用形式。从所用价值函数类选择 Q，最小化 Bellman 平方残差与保守正则之和。正则先对全部有限动作价值取指数、求和再取对数，使较高值有较大影响；再减去数据动作的平均价值，约束数据外动作相对数据动作的乐观程度：

$$\min_{Q} \ \frac{1}{2}\mathbb{E}_{\mathcal{D}}\big[Q(s,a)-y(s,a,r,s')\big]^2+\alpha\mathbb{E}_{s\sim\mathcal{D}}\left[\log\sum_{a'}e^{Q(s,a')}-\mathbb{E}_{a\sim\widehat{\mu}_{\mathcal{D}}}Q(s,a)\right]. \tag{4.13}$$

其中 $\alpha\geq 0$ 控制正则强度，y 由固定目标网络 Q^- 构造。评价当前 $\pi^{(k)}$ 时，按其下一动作分布取期望，可令 $y=r+\gamma\mathbb{E}_{a'\sim\pi^{(k)}(\cdot\mid s')}Q^-(s',a')$；控制备份也可以使用规定的动作最大化版本，真终止处都将继续价值置 0。$\widehat{\mu}_{\mathcal{D}}$ 是该状态的数据动作分布。为检查正则修正的方向，对动作价值求导，得到 $\alpha(\mathrm{softmax}(Q)(a\mid s)-\widehat{\mu}_{\mathcal{D}}(a\mid s))$；于是无数据却预测很高的动作受到向下修正，数据动作得到相对支撑。连续动作不能直接枚举有限和，须按规定采样分布近似相应积分。

沿用例 4.16 的动作与日志，另设教学预测 $Q(a_0)=0, Q(a_1)=4$。未见 a_1 的正则梯度约为 0.982α，梯度下降会压低它。这解释了局部抑制机制，却不证明训练后所有 $Q(s,a)$ 都是可信下界。CQL 理论还依赖表格或特定逼近、采样误差、正则强度及策略更新条件；常用版本控制策略期望价值下界，不能扩大为每个动作的逐点下界。

也可以改变继续价值的计算，避免价值训练查询新行动者提出的数据外动作。**隐式 Q 学习**（implicit Q-learning, IQL）从同一状态的数据动作价值中拟合偏向较高值的状态价值，再用它构造 Q 目标。要表达这种偏向，可用**期望分位数**（expectile）：以不对称权重计量高估和低估的平方误差，

[21] A. Kumar, A. Zhou, G. Tucker, S. Levine, *Conservative Q-Learning for Offline Reinforcement Learning* In Advances in Neural Information Processing Systems, 2020, pp. 1179–1191

找出平均损失最小的位置。它不同于按概率质量切分的分位数，还考虑两侧偏差大小。对于平方可积的 X 和 $\tau \in (0,1)$，比较所有实数位置 υ，定义

$$\ell_\tau(u) = |\tau - \mathbb{I}\{u < 0\}|u^2, \qquad e_\tau(X) \in \arg\min_{\upsilon} \mathbb{E}[\ell_\tau(X - \upsilon)]. \tag{4.14}$$

$\mathbb{I}$ 是指示函数，$u = X - \upsilon$ 为预测偏差。$\tau = 1/2$ 使两侧权重相同，得到均值；$\tau > 1/2$ 加重低估较大 X 的惩罚，使最优 υ 向上移动。对离散分布求导，最优点满足 $\tau\mathbb{E}[(X-\upsilon)_+] = (1-\tau)\mathbb{E}[(\upsilon - X)_+]$。

IQL 在每个状态按数据动作分布形成上述随机变量 $Q(s,a)$。以下回到无限折扣价值，保持固定数据；$Q_{\bar\theta}$ 为固定目标网络，V_ψ 为状态价值网络。先在各自参数类中最小化 L_V 拟合上侧位置，再最小化 L_Q 拟合奖励加继续价值，最后最小化 L_π，用优势指数提高较好数据动作的拟合权重：

$$\begin{aligned} L_V(\psi) &= \mathbb{E}_{(s,a)\sim\mathcal{D}}\ell_\tau(Q_{\bar\theta}(s,a) - V_\psi(s)), \\ L_Q(\theta) &= \mathbb{E}_{\mathcal{D}}[Q_\theta(s,a) - r - \gamma V_\psi(s')]^2, \\ L_\pi(\phi) &= -\mathbb{E}_{(s,a)\sim\mathcal{D}}[\exp(\beta\widehat{A}(s,a))\log\pi_\phi(a\mid s)], \\ \widehat{A}(s,a) &= Q_{\bar\theta}(s,a) - V_\psi(s). \end{aligned} \tag{4.15}$$

每次更新将目标量固定，真终止时 $V(s') = 0$。$\beta \geq 0$ 是逆温度，控制优势差怎样转为相对拟合权重。可先完成价值拟合再提取策略，也可交替训练，但策略梯度不反向改变价值目标。实践中还使用双 Q 较小值和权重截断，须报告阈值。上侧 expectile 施加在同状态的动作价值上，而 Q 平方回归仍平均奖励及随机转移，不挑选幸运反馈。原 IQL 用分开的 V、Q 目标保持了可选择动作与不可选择环境结果的区别[22]。

[22] I. Kostrikov, A. Nair, S. Levine, *Offline Reinforcement Learning with Implicit Q-Learning* In International Conference on Learning Representations, 2022

示例 4.18　三个动作的 IQL 更新与提取　在教学状态 s，三个数据动作等频出现，目标 Q 值为 0、1、3，取 $\tau = 3/4$。为找状态价值，先假设 $\upsilon \in [1,3]$，将一项低估与两项高估按损失权重平衡：

$$\tfrac{3}{4}(3-\upsilon) = \tfrac{1}{4}[(\upsilon - 0) + (\upsilon - 1)],$$

解为 $\upsilon = 2$，确实落在假设区间；损失凸，故为全局最优点。对到达 s 的非终止转移，若奖励 0.5、$\gamma = 0.9$，继续价值便给出 Q 回归目标 $0.5 + 0.9(2) = 2.3$。

提取策略时取 $\beta = \log 2$。三个优势 $-2, -1, 1$ 对应未归一化权重 $1/4, 1/2, 2$。策略若可在所有分类分布中选择，则最大化加权对数似然等价于按等频数据的权重归一化，得到

$$\pi(a_1 \mid s) = 1/11, \quad \pi(a_2 \mid s) = 2/11, \quad \pi(a_3 \mid s) = 8/11.$$

若这些 Q 恰好等于单步真实奖励，提取策略的真实价值为 26/11，高于等频行为的 4/3，仍低于总选 a_3 的 3。这一特殊情形也说明，拟合所得 $V = 2$ 不等于执行策略价值 26/11。

算法 4.1　固定经验上的 IQL 与策略提取

输入： 固定 $\mathcal{D}$，γ, τ, β，价值与策略更新预算，权重截断阈值
输出： 可执行 π_ϕ 及送往独立评价的数据职责说明

初始化 $Q_\theta, Q_{\bar{\theta}}, V_\psi, \pi_\phi$
for 每次价值更新 **do**
　从 $\mathcal{D}$ 抽取转移批次，按 L_V 拟合数据动作 Q 值的 expectile
　按真终止标记屏蔽继续价值，构造固定目标 $r + \gamma V_\psi(s')$
　按 L_Q 更新评论家，再缓慢更新目标 Q 参数
end for
for 每次策略提取更新 **do**
　固定价值网络，计算数据动作优势和截断后的指数权重
　最小化加权负对数似然 L_π
end for
固定提取策略，按第 4.3 节评价，不以 V 直接充当最终证据

算法 4.1 按给定更新预算先拟合价值，再用固定价值提取动作分布，最后将执行策略送往评价。表 4.9 进一步对照提取方式：同一价值函数经不同动作来源形成不同策略，其逼近误差与覆盖风险也不同。

提取方式	动作来源与价值查询	逼近误差	覆盖风险
直接贪心	全动作优化或行动者提出动作；查询其 Q 值	动作优化不精确、评论家误差	容易主动寻找数据外高估动作
优势加权拟合	用数据动作训练执行分布；训练查询数据 Q 值	策略族与加权分布不匹配、优化误差	连续输出仍可能落在稀疏间隙
行为采样后筛选	生成 m 个候选，按 Q 取最大或重采样	行为生成偏差、有限 m 误差	生成概率非零不证明环境后果有支持

表 4.9　价值学习之后的三个动作接口。增大候选数或策略容量可能减少提取误差，也可能更充分地利用价值外推误差。

扩散模型也可接入这些动作提取方式。Diffusion-QL 拟合条件动作扩散模型，并在去噪目标外最大化生成动作的价值，让价值梯度经生成过程改变策略。行为建模与价值驱动训练由此结合，去噪步数则同时影响训练和推理成本[23]。IDQL 研究价值目标对应的行为重加权分布，以扩散行为模型生成候选，按评论家导出的权重重采样，或采用贪心提取变体。它试图减少简单行动者无法表示多模态隐含策略的误差；生成候选仍不提供新的环境后果证据[24]。

图 4.7 区分价值梯度改变生成器与价值筛选已有候选。流模型也能生成候选或给出可微动作映射；要据此说明改进，仍须接入有依据的价值加权、策略目标或规划准则。单独拟合条件生成模型没有完成这一比较步骤。

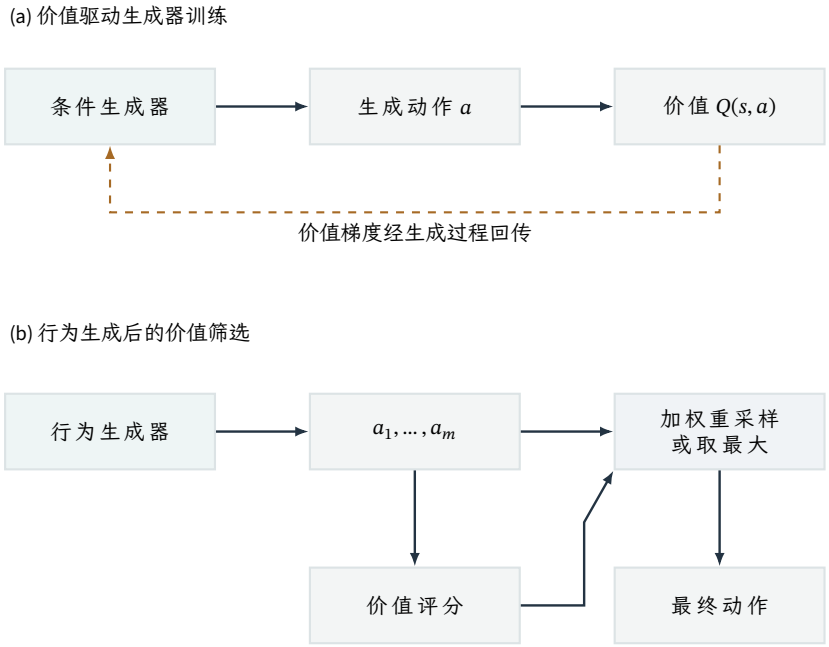


图 4.7 生成式动作的两种价值接口。实线为部署时的候选与动作流，虚线为训练中从价值目标进入生成器的梯度；两条路径不应混称为同一种“扩散策略改进”。

动作还可以组合为序列。近期 DEAS 通过与显式行动者分离的价值学习，减轻动作块评价的过估计，其 ICLR 2026 正式版本研究长时程离线任务与动作序列模型。动作块减少显式选择次数，却扩大了组合动作空间；固定长度序列也不等于能够中途依反馈行动的 Option，更不说明日志覆盖全部动作块。这里只将 DEAS 作为该接口的近期研究，基准表现不构成普遍最优性结论[25]。

[25] C. Kim, H. Lee, Y. Seo, K. Lee, Y. Zhu, *DEAS: DEtached Value Learning with Action Sequence for Scalable Offline RL* In International Conference on Learning Representations, 2026

4.4.4 学习模型上的规划与策略优化

第 3 章允许新交互，因此规划器查询到模型的可疑预测后，还可采样校正；固定经验下无法这样验证。我们仍可从日志拟合 $\widehat{R}(s,a)$ 和 $\widehat{P}(s' \mid s,a)$，并计算不确定性分数 $u(s,a)$。留出数据能检查其覆盖区域中的部分预测误差；数据外的真实后果却不能仅由小误差、小集成分歧或高似然证明。

MOPO 在模型滚动时扣除不确定性惩罚：从日志状态出发，按当前策略在 $\widehat{P}$ 中生成有限长度轨迹，以 $\widetilde{R} = \widehat{R} - \lambda u$ 作为模拟奖励，再混合真实与模拟转移更新策略并重复这一过程。模型只由真实 $\mathcal{D}$ 拟合，模拟转移保留来源标识。滚动长度控制误差可累积的范围，λ 调节不确定区域的惩罚[26]。

[26] T. Yu, G. Thomas, L. Yu, S. Ermon, J. Zou, S. Levine, C. Finn, T. Ma, *MOPO: Model-based Offline Policy Optimization* In Advances in Neural Information Processing Systems, 2020

要把惩罚后的回报解释为真实价值下界，需要知道它扣除的量能否覆盖模型误差。固定 π 和无限折扣目标，令 $\widehat{d}^{\pi}$ 为 $\widehat{P}$ 下的归一化占用。为计

方法	限制位置	候选轨迹来源	真实数据依赖	保守程度与代价
MOPO	模型奖励减去误差代理惩罚	日志状态出发的短模型滚动	动力学拟合及误差校准	惩罚系数、滚动长度；可能拒绝高回报稀疏区域
MOReL	不可信区域进入低回报吸收态	悲观模型中的规划或学习	可信区域判定与模型置信	阈值与吸收惩罚；错误拒绝会缩小可达策略类
COMBO	真实与模型数据上的保守价值正则	学习模型中的策略滚动	模型拟合及数据动作的价值支撑	正则及混合比例；过强会压低真实可行动作

表 4.10 模型法限制外推的三个位置。比较成立的前提是任务、日志、模型容量与查询预算相同；减少显式不确定性估计不等于不再需要误差依据。

算真实价值减去模型价值，将两个 Bellman 方程相减，并按模型轨迹的访问概率累积，得到

$$J_M(\pi) - J_{\widehat{M}}(\pi) = \frac{1}{1-\gamma}\mathbb{E}_{\widehat{d}^{\pi}}\left[R - \widehat{R} + \gamma(P - \widehat{P})V_M^{\pi}\right]. \tag{4.16}$$

这里 $(P - \widehat{P})V$ 是两核给出的下一价值期望之差。共同 ρ_0 和有界价值使折扣尾项消失；占用已归一化，故保留 $1/(1-\gamma)$。若在该策略访问区域内，$|R - \widehat{R}| \le u_R$ 且 $|(P - \widehat{P})V_M^{\pi}| \le u_P$，则每处误差项不低于 $-u_R - \gamma u_P$。按同一非负占用分布平均，得到扣除奖励与转移价值误差上界后的保守回报：

$$J_M(\pi) \ge \frac{1}{1-\gamma}\mathbb{E}_{\widehat{d}^{\pi}}[\widehat{R} - u_R - \gamma u_P].$$

因此，λu 只有与实际误差上界建立联系，才具有上述下界含义。用它选择策略时，条件还须同时覆盖参与选择的候选，不能沿用单个预固定策略的界。所有集成模型也可能一致地学错；没有覆盖或正确结构支撑时，模型分歧仍只是启发式诊断。

除惩罚奖励外，MOReL 在不可信状态动作处转入低回报吸收状态，使规划器少离开可信区域[27]。COMBO 对模型滚动状态动作施加保守价值正则，不必先构造同一种显式不确定性分数[28]。两者都仍需要真实数据和各自保证中的模型误差条件。表 4.10 在相同日志缺口下比较这些选择：未见动作若实际很好，保守限制会放弃可实现回报；若实际很差，限制可能阻止规划器利用错误预测。

另一种模型使用方式是直接生成整段轨迹。Trajectory Transformer 自回归地预测状态、动作与奖励序列，规划时用束搜索保留高评分候选，再执行选中轨迹的首个动作；收到真实观测后重新搜索。改进还取决于搜索评分与候选可行性，不能仅由下一 token 预测损失推出。Diffuser 按当前状态等条件，通过回报引导的扩散采样形成计划，也可执行首个动作后滚动重规划。前者搜索自回归候选，后者引导去噪生成计划，但两者轨迹都是模型预测，没有增加观测经验[29,30]。

[27] R. Kidambi, A. Rajeswaran, P. Netrapalli, T. Joachims, *MOReL: Model-Based Offline Reinforcement Learning* In Advances in Neural Information Processing Systems, 2020

[28] T. Yu, A. Kumar, R. Rafailov, A. Rajeswaran, S. Levine, C. Finn, *COMBO: Conservative Offline Model-Based Policy Optimization* In Advances in Neural Information Processing Systems, 2021

[29] M. Janner, Q. Li, S. Levine, *Offline Reinforcement Learning as One Big Sequence Modeling Problem* In Advances in Neural Information Processing Systems, 2021

[30] M. Janner, Y. Du, J. Tenenbaum, S. Levine, *Planning with Diffusion for Flexible Behavior Synthesis* In Proceedings of the 39th International Conference on Machine Learning, 2022, pp. 9902–9915

部署接收反馈并重规划，不说明训练期间有在线调参权限。若为选超参数反复在真实环境执行计划，这些查询须计入第 4.5 节的新增预算。搜索与模型滚动的通用计算见第 2、3 章；固定日志下，规划器仍不能自行验证数据外预测。

4.4.5 策略改进的保证与比较

前述三类限制都产生了候选，但候选价值超过估计基线还不等于真实改进。需要先规定比较哪些策略，以及估计误差能否同时约束它们。下面固定候选集合与基线，用共同误差事件计算选择后策略最多可能损失多少回报，不依赖特定网络或优化器。

定理 4.19 共同误差事件上的基线性能控制 固定任务、初始分布、时域口径、候选策略集合 Π 及基线 π_b。在共同事件 $\mathcal{E}$ 上，假设每个 $\pi \in \Pi \cup \{\pi_b\}$ 均有 $|\widehat{J}(\pi) - J(\pi)| \le \varepsilon$。从 Π 中选出的策略 $\hat{\pi}$ 若满足 $\widehat{J}(\hat{\pi}) \ge \widehat{J}(\pi_b)$，则该事件中真实价值满足

$$J(\hat{\pi}) \ge J(\pi_b) - 2\varepsilon.$$

若 $\mathbb{P}(\mathcal{E}) \ge 1 - \delta$，结论也以至少 $1 - \delta$ 的概率成立。

证明 为把估计上的选择规则转为真实价值比较，在共同事件内插入候选和基线的估计值：

$$\begin{aligned} J(\hat{\pi}) &\ge \widehat{J}(\hat{\pi}) - \varepsilon \\ &\ge \widehat{J}(\pi_b) - \varepsilon \\ &\ge J(\pi_b) - 2\varepsilon. \end{aligned}$$

第一、三步分别使用 $\hat{\pi}$ 与 π_b 的共同误差界，第二步使用选择规则。事件 $\mathcal{E}$ 发生时这条链必成立，故结论概率不低于 $\mathbb{P}(\mathcal{E})$。 ■

这一界允许真实回报比基线低 2ε，并不保证严格提高。将选择阈值提高到 $\widehat{J}(\hat{\pi}) - \widehat{J}(\pi_b) > 2\varepsilon$，同样推导才给出严格正的真实增量。共同事件是关键条件：预固定单策略的 95% 区间不能直接约束从许多候选中选出的最好者；候选集若由评价数据生成，还须处理适应性。

也可以在候选形成时保留基线对稀少数据区域的行为。SPIBB 用基线自举实现这一约束，即数据少处沿用基线，其他动作才重新分配概率。有限 MDP 中以计数阈值 $N_{\min}$ 识别稀少对，令 $\mathcal{B} = \{(s,a) : N(s,a) < N_{\min}\}$，其中 $N(s,a)$ 为数据计数。要求 $\mathcal{B}$ 内 $\pi(a \mid s) = \pi_b(a \mid s)$，在其余动作上优

共同报告项	行为克隆	可复现行为策略	等预算离线改进方法
价值证据	留出 OPE 或独立测试；不是拟合准确率	原始版本、真实测试或日志回报及其条件	同一评价器、置信处理和查询权限
偏离与悲观设置	模型容量、拟合与动作输出形式	原收集分布与版本	行为惩罚、价值惩罚、模型可信阈值
训练成本	数据遍历、批量、更新次数	复现基线所需成本单列	评论家、生成器、模型及调参总成本
推理成本	一次动作预测或采样	原控制器调用成本	候选数、去噪步数、搜索与滚动长度

表 4.11 方法比较的报告口径，而非虚构的实验结果表。真实测试、离线估计和理论性能界分别标注，不能放在同一列中当作等强度证据。

化经验模型价值。例如基线动作概率 $(0.6, 0.3, 0.1)$ 的第三项稀少，则保持 0.1，而不是删去它再归一化；剩下 0.9 的概率可以在前两项间调整。

原始 Π_b-SPIBB 界依赖有限状态动作、有界奖励、已知且可执行的基线、按计数建立的模型置信条件及规定的受约束求解，控制的是相对基线容许损失。损失还随置信半径、折扣累积和经验模型增益变化，所以名称中的“安全”不表示每次运行超过基线。神经网络近似、模型误设或基线概率错误都不能直接继承表格结论[31]。

表 4.11 将训练收益、证据类型及成本分别报告。基线本身可能回报很低，也可能违反业务安全要求，因此接近基线既不表示接近全局最优，也不说明满足碰撞概率或资源成本约束。本节只控制给定条件下的相对回报；执行安全和约束保证由第 8 章展开。

[31] R. Laroche, P. Trichelair, R. Tachet des Combes, *Safe Policy Improvement with Baseline Bootstrapping* In Proceedings of the 36th International Conference on Machine Learning, 2019, pp. 3652–3661

4.5 有限新增经验下的策略修正

回到定理 4.11，原日志只含 a_0 的零奖励，无法区分两环境。若权限放宽，执行一次 a_1，确定性奖励 $+1$ 或 -1 便能排除一个解释。这里新增的是实际动作后果，而非一次模型预测。奖励有噪声时，一次查询通常还不能辨清环境，获得查询权限也不意味着估计误差已经可忽略。

这种信息补充必须服从每轮协议：开始前声明可执行策略、步数、重置次数、专家帮助权限和验证用途。专家动作与主动随机探索的选择机制不同，新增日志要记录实际机制。即使用于最终报告而不参与梯度更新，试跑也消耗真实交互预算。

新经验加入后，原离线保守构造也要随证据重查。行为约束过强会挡住已有新数据支持的动作，突然取消又可能让尚未校准的评论家驱动危险外推。AWAC 将离线与在线经验用于优势加权动作拟合，减少对显式行为密度的依赖[32]。IQL 也可将新经验接入原有 V, Q 与加权策略计算。Cal-QL 则处理保守初始化的数值尺度：在下估当前策略价值时，用参考策略价值

[32] A. Nair, A. Gupta, M. Dalal, S. Levine, *AWAC: Accelerating Online Reinforcement Learning with Offline Datasets* In arXiv preprint arXiv:2006.09359, 2020

起点	新旧经验混合	评论家变化	行为限制变化	探索恢复要点
AWAC	旧日志与在线回放用于动态规划和优势拟合	用当前继续策略的价值更新优势	加权似然的隐式接近度随数据改变	行动者必须真正产生可补足覆盖的新动作
IQL 微调	新转移加入价值和策略训练	数据动作 expectile 与 Q 目标随新分布变化	温度、截断和混合比例决定偏离程度	不查询数据外 Q 不等于主动探索已经充分
Cal-QL	离线初始化后混合在线经验	参考价值校准限制过度低估	保守强度与新证据一起检查	减轻初始价值尺度失配，仍需覆盖新增行为

表 4.12 有限交互修正中的组件职责。三行不是新的互斥算法分类；混合比例、约束强度和探索预算都需报告，不能只比较最终训练步数。

限制过度压低，减少微调初期仅为恢复尺度所作的更新。这是价值尺度校准，不是任意任务的概率校准保证[33]。

表 4.12 列出的组件可以接入同一轮修正。算法 4.2 先收集并更新数据，再形成候选，最后重新评价。新经验同时改变覆盖与行为分布，所以旧评价器的概率和误差条件也需要重新核对。

算法 4.2 一轮有限经验修正

输入： 当前日志 $\mathcal{D}^{(k)}$、基线、候选，收集预算 B_k 与独立评价预算 E_k
输出： 更新后的候选集合与本轮可支持的性能结论

1: 固定本轮收集策略及版本，声明可访问状态、重置和帮助权限
2: 在 B_k 内收集经验，保存策略概率、轨迹边界及用途标识
3: 构成 $\mathcal{D}^{(k+1)}$，重新检查覆盖及新旧数据混合权重
4: 更新表示、价值、行为或环境模型，按选定接口提取候选
5: 固定待比较策略，在保留日志或 E_k 内的独立交互上重新评价
6: 依据置信规则保留、替换或拒绝候选，记录下一轮需要补充的信息
7: 扣除收集、验证、重置及专家调用预算；预算用尽时停止

除了总预算，协议还决定动作能否根据上一批反馈改变。下面在相同两次查询下，只改变反馈可以进入决策的轮次。

示例 4.20 相同两次查询与不同适应轮次 沿用两个单步环境：a_0 奖励 0，a_1 分别恒为 $+1$ 或 -1。为教学比较，假设先验各为 $1/2$，共允许两个新回合，每回合一次动作。

两次动作若都须在取得反馈前确定，预先选几次 a_1 都使两环境的平均收集回报为 0。允许分两轮时，可先执行 a_1，正奖励后再选 a_1，负奖励后改选 a_0；两环境总回报为 2 和 -1，先验平均为 $1/2$。

这项差距属于收集期间总回报，不是所有最终指标的差距。若只要求收集结束后确定动作，一次性设计中安排一次 a_1 也可辨认环境。相同样本预算配合不同反馈时机，仍可能产生不同的行动过程，因此多轮方法须报告原日志、每轮新增预算和反馈使用时机，并将反复测试的选择偏差纳入证据处理。

[33] M. Nakamoto, Y. Zhai, A. Singh, M. S. Mark, Y. Ma, C. Finn, A. Kumar, S. Levine, *Cal-QL: Calibrated Offline RL Pre-Training for Efficient Online Fine-Tuning* In Advances in Neural Information Processing Systems, 2023, pp. 62244–62269

4.6 两类信息限制叠加时的强化学习

4.6.1 两类限制下的决策目标与可用信息

此前讨论了怎样用历史表示处理执行时状态不可见，离线评价则暂时假设日志记录完整状态。现在撤掉完整状态假设并保留固定经验：日志中的历史未必包括收集者实际使用的所有线索。因此，不能只将评价式中的 s_t 换成 $\boldsymbol{z}_t$。需要先固定目标量，再分别核对执行策略可用的信息、日志保存的信息和行为策略当时使用的信息。

以下恢复有限时域 H，固定 ρ_0、$0 \le \gamma < 1$ 和执行可得历史 h_t，以 Π 表示允许的历史策略类。可以针对一个 $J_H(\pi)$、两个候选的差或相对基线增益提出问题；若要找 Π 内的最优行为，就需要比较全部相关候选。一个候选可评价，只回答该候选的问题，不足以推出能够找到全局最优。

执行可用信息	日志实际字段	行为策略曾使用的信息
只见位置与历史动作、奖励	同样的全回合历史与边界	同样历史及独立随机数：可建立历史条件校正
可以保留起始提示	日志只保留最近窗口	收集者记住提示：执行输入与记录信息不匹配
只见传感观测	记录动作概率但缺少概率所条件化的上下文	专家还看到未记录状态：不能把边缘频率当成随机分配机制
回合开始重置记忆	片段无回合标识、无前缀	行为控制器跨片段保留记忆：初始化机制未知

表 4.13　离线 POMDP 中的三套信息。动作概率需要连同其条件信息和收集协议解释；一个额外字段不能自动修复全部缺口。

表 4.13 第二行的日志缺少部署可保留的提示，因而无法构造待评价策略的输入；第三行缺少专家选动作的依据，还可能改变动作分组与结果之间的统计关系。这两种遗漏都涉及不可见信息，却阻断评价的不同步骤。要判断模型是否足够，应按当前价值或动作比较检查，而非要求恢复所有隐藏状态名称。

定义 4.21　给定问题上的决策等价　决策等价以给定的允许策略类、时域、初始条件与目标结论为条件。两个潜在模型若对该问题涉及的全部价值或动作比较给出相同结论，则在该问题上决策等价。该等价不要求隐藏状态名称一致，也不延伸到未声明的新奖励或策略类。

例如，交换隐藏状态名称会改变参数表示，却不改变任何可执行策略的价值，控制无需唯一的隐藏语义。两个同样预测原日志的模型则可能在强制执行别的动作后给出不同后果；这种差异会改变策略判断。先声明目标结论，才能确定哪些模型差异必须识别。

4.6.2 策略结论的可识别程度

以表 4.13 为起点，离线 POMDP 至少要核对三个条件。历史应保留执行输入并具有正确回合边界；行为应只依据记录历史和独立随机化，或满足另一个明确识别条件；目标历史动作应有行为支持。物理状态隐藏不等于行为机制不明：控制器若也只见记录历史，隐藏状态虽影响反馈，却没有额外进入动作选择。

日志未必能对每个目标都满足这些条件。为了说明已有信息到底排除了哪些解释，可以把具有同一可观测总体分布、又满足既定结构假设的模型保留下来，再查看它们对目标量给出了哪些答案。

定义 4.22 一致模型集合与识别集合 给定可观测日志总体分布 p_{obs} 与结构假设集合 $\mathcal{A}_0$，一致模型集合定义为

$$\mathcal{M}(p_{\mathrm{obs}},\mathcal{A}_0)=\{M : M\text{满足}\mathcal{A}_0\text{且产生}p_{\mathrm{obs}}\}.$$

每个 M 同时指定潜在环境与相容的数据生成机制。将目标量 $T(M)$ 在这些模型中的取值收集为识别集合 $\mathcal{I}_T=\{T(M) : M\in\mathcal{M}\}$，假设 $\mathcal{M}$ 非空。$\mathcal{I}_T$ 为单元素时，T 被点识别；若非单元素但严格包含在预先允许范围内，则得到部分识别。对于策略排序，需单独检查所有允许模型是否给出相同次序；若存在相反排序，则排序不可识别。

确定数值与确定决策是不同要求。例如，性能差 $T(M)=J_M(\pi_1)-J_M(\pi_2)$ 若原可取 $[-10,10]$，日志和结构将其缩小到 $[-1,2]$，便已提供部分数值信息，但正负值仍并存，不能排序。若缩小到 $[1,2]$，数值仍未唯一确定，符号却足以说明 π_1 较好。下面按目标是否点识别、是否只有部分范围、是否仍不能回答决策展开；部分识别本身不等于无法决策。

一致模型和识别集合描述总体分布已知时的限制，有限日志还会引入采样误差，需要再构造相应目标量或识别集合的统计置信集合。一个模型拟合有限日志很好，既没有排除其他总体相容模型，也没有单独控制采样误差。

行为机制是否含有额外隐藏依据，是其中一个关键区别。**隐藏混杂**（hidden confounding）指未记录变量同时影响动作选择与后果，观察到的动作组因而不能直接代表随机试验组。图 4.8 对照普通隐藏状态与这种共同原因；箭头是声明的因果生成假设，不是拟合日志自动发现的事实。

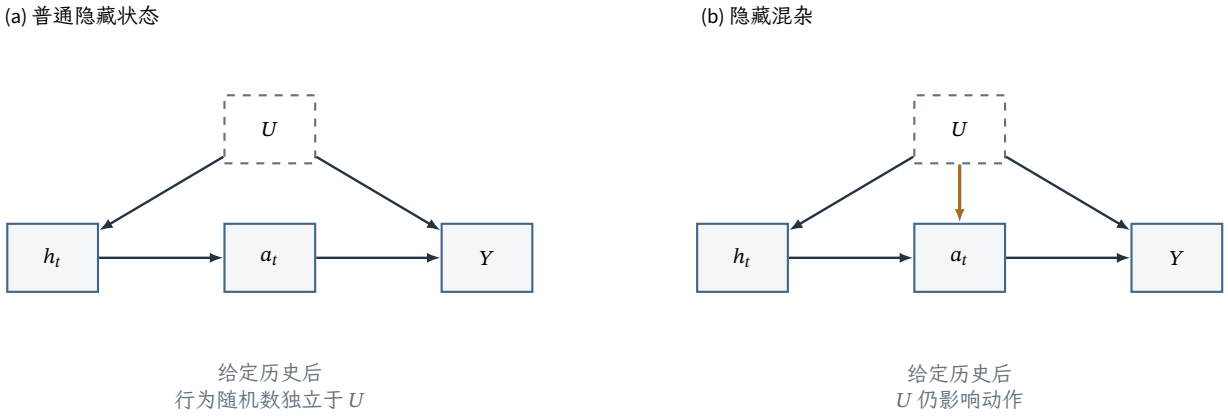


图 4.8 隐藏状态与隐藏混杂的区别。两图中的 U 均未记录，h_t 为记录历史，Y 为未来反馈。左图假设行为仅由 h_t 和独立随机数决定；右图多出 $U \to a_t$，给定 h_t 仍不能阻断动作与后果之间的未记录共同原因。箭头表示因果假设。

示例 4.23 同样日志与相反的动作价值 构造单步教学任务，观测 o 恒定，类型 $U \in \{0,1\}$ 等概率且未记录，专家却能看到它。下面给出两个模型中专家的动作和每种类型执行两动作的潜在奖励：

模型	U	专家动作	$r(a_0)$	$r(a_1)$
M_+	0	a_0	1	3
M_+	1	a_1	-1	1
M_-	0	a_1	3	1
M_-	1	a_0	1	-1

两模型都以 $1/2$ 记录 $(o, a_0, 1)$、以 $1/2$ 记录 $(o, a_1, 1)$。部署看不到 U，若始终选一个固定动作，其价值须按总体类型概率平均该动作后果，而非只平均专家选它的类型：

	$J_1(\pi_{a_0})$	$J_1(\pi_{a_1})$
M_+	$(1-1)/2 = 0$	$(3+1)/2 = 2$
M_-	$(3+1)/2 = 2$	$(1-1)/2 = 0$

因此，相同记录分布在两模型中对应相反的最优固定动作。

只用 o 拟合动作频率，会得到 $\hat{\mu}(a_0 \mid o) = \hat{\mu}(a_1 \mid o) = 1/2$。用它作普通 IS，对任一固定动作目标都算得 $(1/2) \times 2 \times 1 = 1$，既不是 0 也不是 2。边缘上两动作都出现，并未恢复条件随机化：专家选该动作的样本只来自特定类型，不能代表总体类型执行该动作的结果。

有时可以用代理变量补充对隐藏量的间接观测，或增加传感数据，但识别仍需明确的条件独立、可逆性或完备性等结构。字段变多不说明这些条

件成立。部分 POMDP 离策略评价工作利用代理观测和矩阵秩条件处理隐藏机制，不能将这类结论改写为训练循环网络即可消除混杂[34]。

[34] G. Tennenholtz, U. Shalit, S. Mannor, *Off-Policy Evaluation in Partially Observable Environments* In Proceedings of the AAAI Conference on Artificial Intelligence, 2020, vol. 34, no. 6, pp. 10276–10283

4.6.3 完全可识别时的历史表示与决策学习

先考虑不含上述隐藏混杂的一组条件：日志从回合开始完整保留 h_t，行为以已知 $\mu_t(a_t \mid h_t)$ 随机选择，给定历史后的随机数与潜在环境独立；目标也只使用记录历史，初始分布和环境共同，目标轨迹有行为支持。于是每个历史层内的动作按已知机制分配，物理状态隐藏不再给行为增加未知依据。我们可以据此计算目标与行为的观测轨迹比，获得点识别目标价值所需的校正。

为将第 4.3.3 节的校正改到历史输入,写观测轨迹为 $\tau^o = (o_0, a_0, r_0, \dots, o_H)$，将给定历史和动作后的反馈分布记作 $q(y_{t+1} \mid h_t, a_t)$。上述行为条件使目标与行为共享这个反馈因子；按时间分解密度，以目标除以行为，共同初始和反馈项约去：

$$\frac{p_\pi(\tau^o)}{p_\mu(\tau^o)} = \frac{p(o_0)\prod_{t=0}^{H-1}\pi_t(a_t \mid h_t)q(y_{t+1} \mid h_t, a_t)}{p(o_0)\prod_{t=0}^{H-1}\mu_t(a_t \mid h_t)q(y_{t+1} \mid h_t, a_t)} = \prod_{t=0}^{H-1}\frac{\pi_t(a_t \mid h_t)}{\mu_t(a_t \mid h_t)}. \quad (4.17)$$

隐藏状态已在共同反馈因子中积分，因此最终只保留历史条件动作比。也可以先在完整隐藏轨迹上消去共同环境项，再求和隐藏状态；由于两策略的动作概率都只依赖可见历史，才能将它们提出该求和。

这一消去不能通过将 h_t 随意替换为 o_t 保留。行为若记住早期提示，只按当前画面拟合出的边缘频率就不是实际动作条件概率。专家若还看到例 4.23 中的 U，其动作项会随隐藏类型变化，无法从隐藏状态求和中提出，校正便失去依据。

识别条件成立后，可以直接按完整历史评价，或用有依据的充分表示降低计算成本。正确 POMDP 已知时用精确信念，预测结构可识别时可用 PSR；潜在模型、循环或注意力记忆则需要检查允许动作上的预测或控制充分性。相应地，FQE 可以在有限时域历史树上回归，行为约束作用于 $\pi(a \mid h)$，提取动作时查询同一历史或经过论证的充分表示。直接保留历史减少了压缩假设，却可能使历史动作组合非常稀疏。

这些计算仍有表示构造、行为概率估计、有限轨迹采样与优化误差，报告时应分开。训练用 burn-in 恢复记忆，部署却每 L 步清零，会变成不同策略；训练读到回合开始提示，部署只有窗口，也不是原来评价的对象。总体可识别排除了信息上的不可能性，但有限数据、所选网络和优化还未必实现相应估计。

早期提示任务可以将表示错误与不可识别分开。假设行为在每种提示下随机尝试两个出口，完整历史也被记录，则动作价值在总体上可识别。

一个编码器保留 c，另一个只重建走廊图像；延迟很长时，提示帧占平均重建损失的比例很小，两者重建误差可能相近。按原例不折扣成功奖励，前者仍可达到 1，后者至多 $1/2$。此时失败来自编码遗漏，不能解释为环境本来无法识别。

4.6.4 部分可识别时的历史表示与决策学习

若同一日志和结构仍容许多个价值，就需要保留定义 4.22 中的一致模型集合 $\mathcal{M}$，而不是选一个拟合模型当作唯一真相。对于固定 π，比较 $\mathcal{M}$ 内各模型的价值，取下确界和上确界，计算 $[\inf_M J_M(\pi), \sup_M J_M(\pi)]$，作为识别集合的上下包络；也可改变允许的混杂强度，检查敏感性范围。包络只描述最小和最大边界，未必每个中间值都可实现。有限日志还须在外层加入总体分布未知的采样误差。

排序所需的信息可能比单独价值少。固定两个候选，在每个相同模型中先计算 π_1 价值减去 π_2 价值，再对 $\mathcal{M}$ 取下确界。若这个最小边界仍为正，全部允许模型便给出同一排序；只看平均模型不够，因为另一个同样符合日志的模型仍可能反转次序。

定理 4.24　共同模型下的性能差确定排序　给定非空一致模型集合 $\mathcal{M}$，假设两个策略在每个模型中的价值均存在。若

$$\inf_{M\in\mathcal{M}} [J_M(\pi_1) - J_M(\pi_2)] > 0,$$

则所有允许模型都给出 π_1 优于 π_2 的排序，两个单独价值区间即使重叠也不影响结论。

证明　将下确界记为 $c > 0$。定义保证任意同一个 $M \in \mathcal{M}$ 均满足 $J_M(\pi_1) - J_M(\pi_2) \geq c > 0$，于是每个模型的排序相同。比较两策略时未切换模型，下确界也无须由某个模型取到，不等式仍成立。 ■

示例 4.25　不知道共同偏移，仍知道谁更好　构造由 $u \in [0, 10]$ 参数化的一致模型，并令 $J_u(\pi_1) = u + 1$、$J_u(\pi_2) = u$。两个价值包络 $[1, 11]$ 与 $[0, 10]$ 大幅重叠，同一模型中的差却恒为 1，因此 π_1 总较好。若将单独包络端点相减，$1 - 10 = -9$ 对应为 π_1 取 $u = 0$、为 π_2 取 $u = 10$；这是松的包络差，不是任一共同模型的真实性能差。

这里两候选共享未识别收益 u，而“多得 1”由额外结构假设给定，不能从拟合日志自行宣称。若允许策略只有 π_1, π_2，为使选择在每个相容模型中都有依据，可以先各自对 $u \in [0, 10]$ 取最坏回报，再在两策略中最大

化；最坏价值 1 和 0 会选中 π_1。直接计算相对 π_2 的共同模型差下界则给出改进 1。若另加不得偏离已覆盖历史的约束，且它排除了 π_1 的新历史，允许类只剩 π_2，这项已由结构支持的改进也被放弃。保守限制可防止无依据推断，也可能因策略类过窄损失回报；系统的鲁棒优化见第 8 章。

增加同类样本可以缩小采样误差，却不会自动排除总体上仍相容的模型。图 4.9 假设总体识别区间 $[1,3]$，仅为示意将外层统计半径设为 $2/\sqrt{n}$。样本增加时，外层范围缩到 $[1,3]$ 而非单点。这是区分两种宽度的解析草图，不是算法经验曲线，也不是已经推导的置信保证。

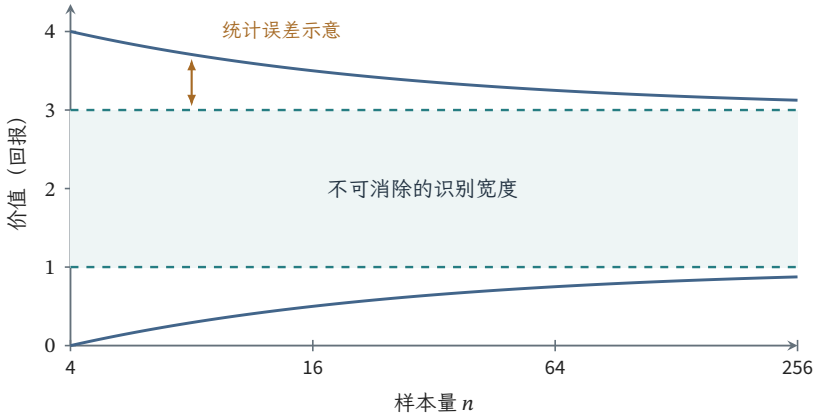


图 4.9　教学识别区间 $[1,3]$ 与示意外层范围 $[1-2/\sqrt{n},\,3+2/\sqrt{n}]$。实线范围随样本量缩小，虚线之间的非零宽度来自允许模型仍有差异；半径公式仅用于解释两种不确定性。

4.6.5　不可识别时的学习边界与信息补充

若一致模型仍支持相反排序，当前目标决策就没有被识别。例 4.23 的日志在两个模型下似然完全相同，最优动作却分别为 a_0、a_1；缺口是专家选择所依据的未记录类型及其他动作的反事实后果。更细的当前观测编码不会补出这些数据，复杂模型收敛到任一解释也不能证明排序正确。

可以通过收缩目标或补充依据继续推进。缩小 Π 只比较日志支持的策略，或将全局最优改为基线附近的有限决策，改变的是要回答的问题。增加已知动力学、行为随机化或代理观测等可核验假设，改变的是允许模型集合。新假设须有外部依据才能排除相容解释，方便拟合的设定不能冒充原日志中的事实。

表 4.14 逐项对应了可能补充的信息。单独补记概率未必够：例 4.23 中专家在每种类型上都确定性行动，即使记录 U，该类型的另一动作仍无支持。识别固定策略价值，还需在允许类型内受控随机行动，或有依据的跨类型、跨动作结构。更长的同类日志不能替代这些行为或结构信息。

明确的信息缺口	可能补充的信息	仍须核验的条件
较早提示未记录	从真实回合开始的长历史或足够记忆摘要	提示是否确实保留；部署可用性与回合边界一致
行为机制不明	当时动作概率、策略版本及相关上下文	概率条件信息正确；潜在类型上的支持仍可能缺失
当前状态混叠	新传感器、主动辨识动作或代理变量	新观测能否区分与控制有关的状态；代理识别条件
目标行为无覆盖	受控随机交互、指定区域的实验	查询确实覆盖目标历史动作；代价和安全权限允许
初始或任务条件不明	初始状态、目标及采样分层元数据	评价分布与部署分布一致，或有正确校正

表 4.14 补充信息要对应具体缺口。记录隐藏类型可以消除部分混杂，却未必补齐每种类型下未尝试的动作；新增字段与新增行为各有不同作用。

若允许有限交互，可以分别安排状态辨识与策略验证预算。辨识选择能区分相容模型的传感或动作，并在需要时更新表示；验证则固定新策略及输入协议，取得独立性能证据。辨识中的自适应数据不能未经处理便当作独立最终测试。权限不足，或新反馈仍在相容环境中同分布时，无法判断的结论应保留。网络容量可帮助降低表示或拟合误差，却不能从相同输入辨清本来不可区分的环境。

4.7 本章小结

章首的小车问题现在可以分别回答。速度不可见时，需要由历史保留线索，或用信念与记忆形成决策依据；缺少左转经验时，需要检查收集机制与覆盖，判断左转后果能否从日志确定。Tiger 说明模型已知仍可能值得付费辨认当前状态，未覆盖动作反例则说明状态完全可见也仍可能无法识别价值。仅增加记忆不能补齐动作后果，仅补充同类行为也不能找回未记录的线索。

即使识别排除了相容环境给出不同答案的歧义，估计仍需控制有限样本、模型与概率误差。优化又会改变被查询的行为，可能利用估计外推；由价值、行为生成器或轨迹模型提取的执行策略，最终仍须在共同评价条件下比较。行为约束和悲观目标限制的是偏离或乐观预测，其名称与小训练损失不能代替误差依据。因此，可识别、可估计、可优化与可验证只有附带条件的联系，不会自动相互推出。

两类限制叠加时，执行历史、日志字段和收集者信息要共同核对。在完整历史、共同环境与初始条件、正确随机化机制和目标支持下，隐藏状态可从共同反馈项中积分，概率比只含历史条件动作概率。存在未记录行为依据时，相同日志却可能对应相反排序。部分识别仍可能通过共同模型差作出有限决策，排序不可识别时则需收缩结论或补充能区分模型的信息。随策略结论报告执行信息、日志机制、覆盖范围、表示假设、查询预算及误差依据，才能确定它适用于哪里。

第 5 章

奖励受限下的强化学习

一台配送机器人能够移动和避障，我们还需要告诉它怎样才算完成一次好的配送。若只在签收时给分，机器人可能拿到终局成绩，却难以判断早先哪次核对出了错。若每移动一米都给分，它又可能靠绕路增加得分，而不把包裹交给收件人。请人示范路线可以提供一组可用动作，但单凭这些动作，仍难判断示范者看重的是速度、能耗还是包裹完好。这里分别缺少动作贡献的依据、完整的计分标准和足以确定目标的信息，不能用同一种奖励处理办法回答。

第 3章虽然不知道期望奖励，仍假定交互后能读到奖励样本；第 4章检查状态信息和数据覆盖是否足以支持决策。本章保留这些学习工具，改变它们所接收的反馈。我们要分别判断：没有可信的标量奖励时，其他记录能约束哪些行为目标；只有轨迹总分时，怎样用它更新局部决策；训练分数提高时，实际行为是否满足原先的要求。图 5.1说明这三个问题如何共同支持反馈学习。它们是可以叠加的限制，而不是必须依次排除的三种故障。

本章仍用 r_t 表示执行 a_t 后的奖励，用 $J(\pi)$ 表示未归一化的期望折扣回报。为观察反馈落在哪个环节，我们另设一个四步配送任务：机器人依次核对包裹、装载、搬运和交付，状态包含包裹身份、位置及完好情况。这个案例不沿用前文随机网格的精确动力学；除特别说明外，反馈在交付后才给出。本章用于计算的人工数字都是教学假设。

5.1 奖励信号的三类限制

5.1.1 奖励观测受限

机器人不知道一条路线的平均耗电量时，仍可在执行后读取电表，再用样本估计期望奖励。只要电表记录可信，这属于前文的未知奖励学习。若目标改为“把包裹妥善交给收件人”，日志却只记录移动距离，情况就不同了：距离既没有说明交给了谁，也没有说明包裹是否破损。此时缺少表达

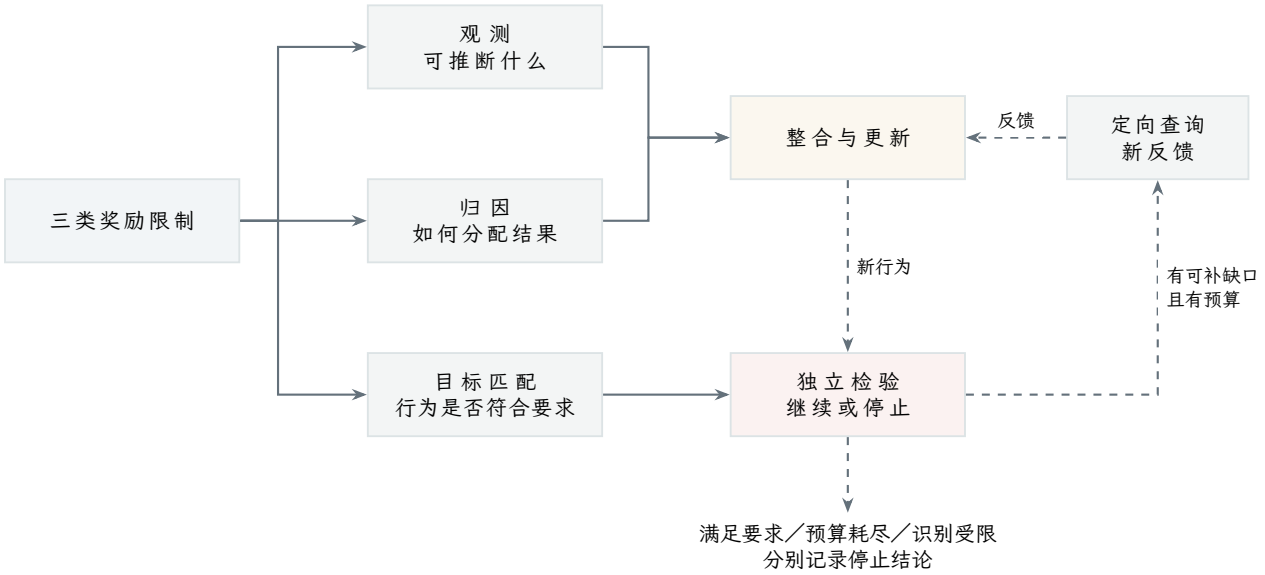


图 5.1 三类奖励限制与反馈学习的关系。实线表示观测、归因和目标匹配分别为反馈整合、策略更新及行为检验提供依据，不规定三者的解决顺序；虚线表示取得新行为和新反馈后进入下一轮。停止可能因为证据已满足要求，也可能因为预算耗尽或关键目标信息无法补足，三者支持的结论不同。

目标的观测，而不只是均值估计不够精确；增加同类距离记录仍不能判断交付质量。

定义 5.1 替代反馈的形式与粒度 示范（demonstration）记录决策者实际采取的行为，可以是某状态上的动作，也可以是整条轨迹。评分（rating）按照约定尺度给被评价对象一个数值。偏好（preference）记录在相同比较条件下，评价者如何排列两个或多个对象。验证反馈（verification feedback）判断对象是否满足指定条件，并可附带检查证据。反馈的粒度（granularity）是这次判断实际评价的单位，可以是动作、步骤、轨迹片段或完整轨迹。记录到达的时间不必等于被评价动作发生的时间。

这些形式保留的信息不同。示范告诉我们“当时做了什么”，没有直接评价未选动作；评分保留数值差距，但比较差值需要统一尺度。偏好可以只给出顺序，不给绝对分数；验证器的通过标记则只支持被检查条件。表 5.1还列出查询权限，因为读取已有示范与继续向专家提问是两种访问能力，前者不能代替后者。

例如，人和模型都可以提供示范、评分或成对偏好。身份核对规则可以返回通过标记，实际执行开箱操作的检查器也可以返回破损结果。这里“人类反馈”回答谁在判断，“偏好反馈”回答判断怎样记录，两者可以同时描述同一条记录，不是互斥类别。

形式	反馈对象	粒度	噪声来源	查询权限	可推断对象
示范	已执行动作与上下文	动作、轨迹	次优专家、漏记信息	固定日志或另行授权的专家查询	行为条件分布；附加理性假设下的奖励约束
评分	单个被评价行为	步骤、片段、轨迹	尺度漂移、反应延迟	可只提供历史评分	该尺度下的评价函数
偏好	同条件候选行为	一对片段或轨迹	次序效应、偏好异质性	固定比较或主动选对	比较概率、相对效用
验证	产物或状态关系	步骤、结果	规则遗漏、执行误差、误判	可离线复查或在线调用	指定条件的通过情况

表 5.1 四种反馈形式及其可用信息。形式说明记录表达什么，查询权限说明还能补充什么。人类、AI、规则和执行器描述反馈来源，同一来源可以产生多种形式。

5.1.2 奖励归因受限

假设日志已准确记录包裹完好且交付成功，我们仍不知道哪些先前决策值得强化：核对身份、平稳搬运和容易的路线都可能与成功同时出现。**奖励归因**（reward credit assignment）要把长期结果联系到先前决策，为局部更新提供贡献判断。第 3章已经用回报、TD 误差和优势估计传播结果；这里要检查这些工具接收的信号包含什么信息，以及哪些贡献仍未被观测。

现象	缺口	主要影响	不能直接推出什么
非零奖励很少	多数尝试没有区分信号	难以探索到成功轨迹	一旦成功就能正确归因
反馈延迟长	行动与反馈相隔许多步	时间信用传播慢、回报方差增大	反馈语义必然错误
只有轨迹总分	局部贡献未被观测	无关动作也可能分享相同结果	每一步都有独立监督
反馈噪声大	相同行为的判断不稳定	估计方差和误排序增加	噪声一定来自时间延迟

表 5.2 影响奖励归因的四种反馈性质。非零奖励少、反馈来得晚、只评价整条轨迹及判断有噪声，可以在同一任务中同时出现，但各自造成的缺口不同。

按照表 5.2，我们可以先区分尚未找到成功行为与已经找到成功行为却不清楚贡献这两种情况。机器人始终找不到收件人时，增加探索或提供成功示范可能补上行为线索。若日志中已有许多成功配送，但身份核对总与无关的扫码动画一起出现，就需要辨认哪一个动作影响结果。重复收集相同组合未必能区分二者；给每次动画播放加分虽然增加了反馈频率，也没有提供更可信的贡献信息。

5.1.3 奖励与行为目标不匹配

若计分规则是每移动一米得一分，机器人可以通过绕圈提高回报，却始终不完成配送。优化器在这种行为上可能正按目标工作，问题出在数值标准没有表达交付要求。要判断这一偏差，我们需要把希望发生的行为与训练实际优化的数值分开。

定义 5.2 奖励、回报、效用与行为要求 单步奖励 r_t 是交互协议返回的标量，累计回报 $G_0 = \sum_t \gamma^t r_t$ 按约定的时间权重汇总这些标量。**效用**（utility）表示决策者如何评价结果或结果分布，可记为 $u(\tau)$ 或策略评价泛函 $\mathcal{U}(\pi)$，不预设它等于 $J(\pi)$。**行为要求**（behavioral requirement）规定希望发生什么以及在什么条件下发生，例如交给正确收件人、保持包裹完好并满足能耗要求。**代理奖励**（proxy reward）是训练所用的数值编码；它是否表达了这些要求，须用独立证据检验。

据此再看三种限制：里程计分即使即时且准确，也可能遗漏任务目标；“正确收件人且完好”的终局标记可以表达明确的成功条件，但早期动作要经过多步才得到反馈。有效路线示范能够帮助行动，却未必确定各项奖励权重。同一任务还可以同时具备三种限制，例如示范不记录破损、评分延迟到终局，训练又额外奖励里程。

选择学习办法要先定位缺口。缺少可靠信号时需要补充目标信息，缺少局部贡献时需要检查结果怎样进入更新，标准遗漏要求时则需要修订目标。训练损失下降只能说明模型更符合所选训练准则，不能同时证明反馈覆盖充分、归因正确和编码完整。交付身份、完好情况及能耗的独立检查应在优化前约定；若事后随行为改变标准，就失去了判定偏差的共同依据。

5.2 奖励观测受限下的强化学习

假设配送日志拿不到可靠的逐步奖励，却保留了专家路线、两条路线的比较或签收检查。我们可以用动作示范直接拟合策略，用偏好约束相对效用，也可以用验证结果形成策略更新信号，不必都先恢复唯一奖励。下面按记录实际表达的内容，判断能从中推断什么，以及推断还依赖哪些假设。

5.2.1 替代反馈与可推断对象

在同一个配送任务中，示范可以记录专家选择电梯，偏好可以记录收件人更喜欢平稳但较慢的配送，身份验证则只检查是否交给正确的人。选择电梯没有单独说明“慢一些更好”，身份通过也没有证明包裹无破损。若把这些记录统一改成“正例”，我们就无法再分清它们支持哪种结论、排除了哪种目标解释。

为了说明这些结论的对象，我们回用前文的记号。策略 $\pi(a \mid s)$ 给出某状态上的动作分布，占用度量 $d^\pi(s,a)$ 汇总长期访问状态和动作的概率；价值 V^π, Q^π 预测给定奖励和策略下的后续回报。奖励 $R(s,a)$ 规定单步期望计分，效用表达评价者怎样看待结果。这些对象相互联系，但一条记录

对其中一个对象提供信息，并不自动唯一确定其他对象。表 5.3列出各类记录可以支持的学习对象。

反馈	候选推断对象	额外假设	训练交互	最终输出
状态动作示范	策略	输入足以解释动作，覆盖可用	行为克隆不需要	动作分布
专家与策略轨迹	占用、软价值	共同环境，轨迹采样口径一致	占用匹配通常需要	策略或价值函数
专家轨迹	奖励、特征期望	专家理性、奖励函数类、动态模型	需规划或采样权限	奖励候选及策略
标量评分	评价函数	尺度、对象与时间归属明确	拟合本身不需要	评分预测器
成对偏好	效用差、策略	比较模型与共同条件	拟合可离线；在线 RL 另需新采样	奖励模型或偏好策略
过程、结果验证	条件通过概率	规则有效、检查前提满足	在线更新需可调用验证	验证信号与策略

表 5.3 不同记录可支持的推断、假设和输出。同一反馈可以用于多个学习对象，同一对象也可以结合多种反馈。“不需要交互”只说明拟合阶段的访问要求，不表示固定数据已覆盖未来行为。

一个单步例子即可看出不唯一性。任务只有左、右两个动作，专家总选左；奖励 $(R(\text{左}), R(\text{右})) = (1, 0)$ 和 $(10, 9)$ 都能使左最优。若记录只保留甲、乙、丙的确定排序，效用 $(3, 2, 1)$ 和 $(100, 2, 0)$ 也都给出甲优于乙、乙优于丙，但它们的效用差不同，未必在同一个随机偏好模型中产生相同比较概率。排序提供的信息比完整比较概率少；即使概率已知，共同加法常数等歧义通常仍然存在。

新增查询能否解除歧义，取决于它提出了什么新问题。若允许主动查询，我们可以比较此前未比较的路线，或询问专家在当前策略偏离后怎样恢复。重复旧记录可以降低采样误差，却不会补出从未涉及的要求。因而这里沿用第 4章的判断顺序：先说明要识别的是动作、排序还是奖励，再检查数据是否足以支持这个结论。

5.2.2 从示范直接学习策略

专家已经给出可用动作时，我们可以先让策略在相似输入上复现这些动作。前章用于拟合日志动作的**行为克隆**（behavioral cloning, BC），在这里以专家状态或记录历史为输入，以专家动作作监督标签。要衡量离散动作策略是否复现了示范，可以惩罚它给专家动作分配过小的概率。设任务有 $t = 0, \dots, H-1$ 这 H 步，专家在各时刻的状态分布为 ν_t^{E}；对这些状态及专家动作取期望，再在时间上平均，得到总体负对数似然

$$L_{\mathrm{BC}}(\theta) = -\frac{1}{H} \sum_{t=0}^{H-1} \mathbb{E}_{\substack{s \sim \nu_t^{\mathrm{E}} \\ a \sim \pi_{\mathrm{E}}(\cdot \mid s)}} \log \pi_\theta(a \mid s). \tag{5.1}$$

最小化该损失，就是在专家访问分布上最大化示范动作的平均对数概率，并不要求每条记录的概率都同时增加。训练时用示范数据 $\mathcal{D}_{\mathrm{E}}$ 的平均负对数似然估计这个期望，再做 $\theta^{(k+1)} = \theta^{(k)} - \eta \nabla_\theta \widehat{L}_{\mathrm{BC}}$，完成一次参数拟合，其中 η 为步长。数据由专家产生，不是当前策略执行得到的；每次遍历都要为记录计算策略概率和梯度，但不需要奖励标签或重新运行环境。

连续动作还可以用平方误差 $\mathbb{E}\|f_\theta(s) - a\|_2^2$ 拟合动作数值；在无限容量下，最小化这个误差得到条件均值。然而，均值未必是可用动作。假设专家绕障时等概率选择 -1 和 1，分别表示左转和右转，均值 0 可能使机器人直撞障碍。要保留两种有效选择，就需表示多模态动作分布，而不只输出平均动作。另一个原因是日志漏记了任务指令，使相同观测对应不同专家动作；单靠增加网络复杂度不能恢复未记录的指令。

动作在专家数据上拟合准确，还不能保证执行时同样准确。专家很少进入错误走廊，克隆策略一旦误入，就要在示范没有覆盖的状态继续决策。为了看清早期错误如何影响后续成本，下面在共同环境中比较专家与学习策略，并用首次动作分歧的概率给出保守上界。

定理 5.3　行为克隆的首次分歧界　考虑共同初始分布、共同转移核的有限时域任务，每步成本 $c_t(s,a) \in [0,1]$，总成本记为 $C_H(\pi) = \mathbb{E}_\pi \sum_{t=0}^{H-1} c_t(s_t, a_t)$。专家 π_{E} 为确定性策略。若学习策略在每个专家状态分布上均满足

$$\mathbb{E}_{s \sim \nu_t^{\mathrm{E}}}\big[1 - \pi(\pi_{\mathrm{E}}(s) \mid s)\big] \le \varepsilon,$$

则

$$C_H(\pi) - C_H(\pi_{\mathrm{E}}) \le \frac{H(H+1)}{2}\varepsilon.$$

非平稳专家可把时间加入状态，结论不变。

证明　将两条轨迹放在同一概率空间中，使它们从相同状态出发，并在尚未出现动作分歧时共用环境转移的随机性。另在完整专家轨迹的每个 s_t^{E} 上，抽取服从 $\pi(\cdot \mid s_t^{\mathrm{E}})$ 的候选动作。令 B_t 表示该候选动作不同于专家动作；定理假设给出 $\mathbb{P}(B_t) \le \varepsilon$。

首次分歧以前，两条轨迹的状态、动作和成本相同，所以截至 t 已发生分歧，只可能是在某个 $j \le t$ 出现了 B_j。这个事件包含于 $\bigcup_{j=0}^{t} B_j$，由并集界，其概率不超过 $(t+1)\varepsilon$。分歧后两条轨迹可以任意发展，但

单步成本均在 $[0,1]$ 内，额外成本至多为 1；未分歧时额外成本为 0。对这一指示变量上界取期望，再按时间求和，

$$C_H(\pi) - C_H(\pi_{\mathrm{E}}) \le \sum_{t=0}^{H-1} (t+1)\varepsilon = \frac{H(H+1)}{2}\varepsilon.$$

并集界使用的是完整专家轨迹上的事件概率，并未假定“此前尚未分歧”条件下的错误率也等于 ε，因此没有额外引入条件分布假设。 ■

由于每步成本至多为 1，总成本差本身还不超过 H，可以将界的右端取为 H 与上述二次项中的较小值。二次项来自一次早期分歧可能影响余下多步的估计，不是所有任务都会二次恶化的断言；若机器人能迅速恢复，实际额外成本可以小得多。

上述缺口发生在学习者实际访问的状态上，因此可以让专家对这些状态补动作标签。**数据集聚合**（Dataset Aggregation, DAgger）反复执行当前策略、查询专家，并把新标签并入训练集重新拟合。它改变训练覆盖，使偏离后的状态也进入下一轮，而不是只增加专家原有轨迹。图 5.2分别画出执行、查询和聚合；Ross 等给出了这一归约及其在线学习分析[1]。

算法 5.1　一轮 DAgger 更新

输入： 已聚合数据 $\mathcal{D}^{(k)}$，策略 $\pi^{(k)}$，专家查询接口，轨迹预算 m
输出： 新数据 $\mathcal{D}^{(k+1)}$ 与候选策略 $\pi^{(k+1)}$

1: 在获准环境中执行 m 条 $\pi^{(k)}$ 轨迹，记录实际访问的状态
2: 对这些状态查询 $a_{\mathrm{E}} = \pi_{\mathrm{E}}(s)$，保留失败及偏离后的状态
3: $\mathcal{D}^{(k+1)} \leftarrow \mathcal{D}^{(k)} \cup \{(s, a_{\mathrm{E}})\}$
4: 在聚合数据上最小化模仿损失，得到 $\pi^{(k+1)}$
5: 在独立轨迹上评价任务表现，并记录查询数与执行风险

例如，当前策略误入 $s_{\text{偏}}$，专家标注“返回”。在二动作策略中，用 logit z 表示返回的对数几率，返回概率为 $\sigma(z)$，其中 $\sigma(z) = (1+\exp(-z))^{-1}$ 将实数转换为概率。若当前 $z = 0$，该标签的负对数似然梯度是 $\sigma(0) - 1 = -1/2$；以 0.2 为步长下降，得到 $z = 0.1$，返回概率由 0.5 升至约 0.525。这次更新利用了原专家示范未覆盖的错误状态。取得这些标签也有成本：每轮执行 m 条 H 步轨迹需要 mH 个环境步、至多 mH 次查询，并要重新拟合不断增长的数据集。

能否持续改善自身访问分布上的模仿损失，可以用在线学习的遗憾来描述：每轮损失在该轮策略访问分布上计算，比较基准则是预先指定策略类 Π 中，同一策略在全部轮次上的平均损失。下面先假定这些总体损失可用；平均遗憾小意味着迭代策略的平均损失接近类内最小值，因而至少有一轮不超过该平均上界。

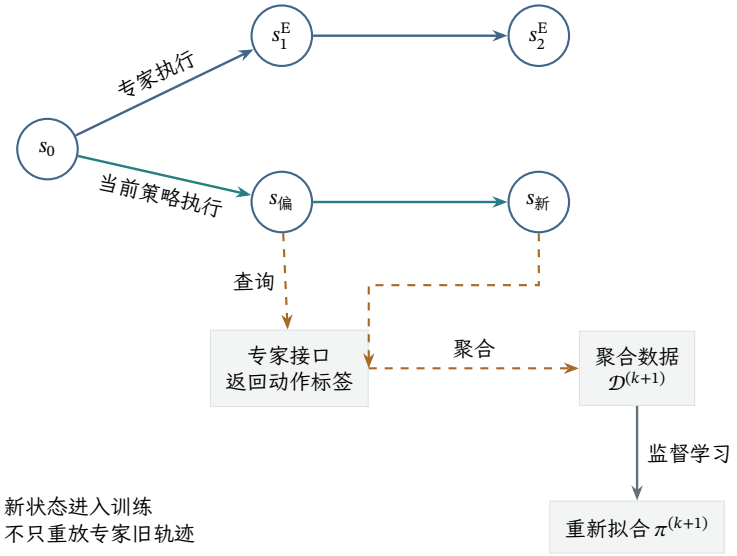


图 5.2 DAgger 补充当前策略偏离后的状态。两条轨迹从同一起点出发，分歧后对当前策略访问的新状态查询专家；新标签随聚合数据进入下一轮。查询只取得动作标签，不表示专家已在环境中执行该动作。

定理 5.4 理想化 DAgger 的无遗憾归约 令 $\bar{\nu}^{(k)} = H^{-1}\sum_t \nu_t^{\pi^{(k)}}$ 为第 k 轮当前策略自身的平均状态分布，定义 $\ell_k(\pi) = \mathbb{E}_{s\sim\bar{\nu}^{(k)}}\ell(\pi;s)$。若 K 轮在线拟合满足

$$\frac{1}{K}\sum_{k=1}^{K}\ell_k(\pi^{(k)}) - \min_{\pi\in\Pi}\frac{1}{K}\sum_{k=1}^{K}\ell_k(\pi) \le \varepsilon_{\mathrm{reg}},$$

则至少一轮 k 满足

$$\ell_k(\pi^{(k)}) \le \min_{\pi\in\Pi}\frac{1}{K}\sum_{j=1}^{K}\ell_j(\pi) + \varepsilon_{\mathrm{reg}}.$$

将遗憾不等式中的比较项移到右侧，就得到各轮自身分布损失的平均上界。再在实际生成的 K 个策略中取损失最小的一轮，利用

$$\min_k \ell_k(\pi^{(k)}) \le \frac{1}{K}\sum_k \ell_k(\pi^{(k)}).$$

即可得到定理的结论。比较策略在所有轮次的分布上评价，分布本身不必相同。这个结果首先约束模仿损失；使用有限样本还要加入估计误差，混合执行专家时还要控制混合分布与自身分布的差异。若进一步推成任务成本界，需要模仿损失能控制动作错误，并且一次错误后专家恢复的额外成本有统一上界。平均遗憾条件本身不足以保证任意实现都具有线性时域成本界。

仅有动作标签时，DAgger 不能直接区分两种错误动作的后续代价。SEARN 将序贯预测转为代价敏感学习，通常通过后续执行估计各动作的代价；AggreVaTe 则聚合当前访问状态上的专家后续成本，使“动作不同但成本接近”也能进入比较。它们比动作查询需要更丰富的信息和更高的获取成本。专家还可能无法评价陌生状态，采集时的策略执行也可能造成风险；读取固定示范不意味着已经获准执行这些查询[2,3]。

[2] H. Daumé III, J. Langford, D. Marcu, *Search-Based Structured Prediction* In Machine Learning, 2009, vol. 75, no. 3, pp. 297–325

[3] S. Ross, J. A. Bagnell, *Reinforcement and Imitation Learning via Interactive No-Regret Learning*, 2014, arXiv: 1406.5979

5.2.3 从示范推断占用与奖励

配送策略可能在常见走廊上选择与专家相同的动作，却在装载区停留更久；只拟合专家已见状态上的动作，尚未比较这种长期访问差异。我们回用归一化折扣占用度量，将不同时刻的状态动作分布按折扣汇总。这里改用 $0 \le \gamma < 1$ 的无限折扣设定，回合结束后以原始奖励为零的吸收状态延拓，并将终止后的占用计入总质量：

$$d^{\pi}(s,a) = (1-\gamma)\sum_{t=0}^{\infty} \gamma^{t} \mathbb{P}_{\pi}(s_t = s, a_t = a). \tag{5.2}$$

该分布同时记录策略怎样选动作以及环境允许到达哪些状态。在共同环境中，完整占用匹配不仅要求已见状态上的动作相符，还约束这些状态出现的频率。对于平稳马尔可夫策略，在 $d^{\pi}(s) > 0$ 处可以由 $d^{\pi}(s,a)/d^{\pi}(s)$ 恢复动作分布。比较前必须将专家和策略样本按同一折扣及吸收延拓方式加权；若在不同长度回合中均匀抽取非终止转移，通常得到的是另一种采样分布，不是这里的 d^{π}。

生成对抗模仿学习（generative adversarial imitation learning, GAIL）用判别器识别状态动作来自专家还是当前策略，再更新策略，使两种来源更难区分。令 $D_{\omega}(s,a)$ 为判别器给出的专家来源概率。判别器在允许的概率函数中最大化正确来源的对数似然，策略在共同环境可实现的策略中最小化这一可区分程度，并以非负权重 λ 鼓励动作熵。使用归一化占用，可写为

$$\min_{\pi} \max_{D} \{\mathbb{E}_{d^{\mathrm{E}}} \log D + \mathbb{E}_{d^{\pi}} \log(1-D) - \lambda \mathcal{H}_{d}(\pi)\}, \tag{5.3}$$

其中 $\mathcal{H}_{d}(\pi) = \mathbb{E}_{d^{\pi}}[-\log \pi(a \mid s)]$ 在策略访问分布上计算动作熵。若暂不限制判别器函数类，固定两份占用，在有总质量的位置逐点最大化判别项，得到 $D^{*} = d^{\mathrm{E}}/(d^{\mathrm{E}} + d^{\pi})$；代回判别项，得到 $-\log 4 + 2\,\mathrm{JS}(d^{\mathrm{E}} \| d^{\pi})$。这里 JS 是 Jensen–Shannon 散度，即分别计算两个分布相对于它们平均分布的 KL，再取平均；值越小表示访问分布越难区分。这个推导说明判别器提供的是占用差异的度量，不是唯一真实奖励的识别结果[4]。

[4] J. Ho, S. Ermon, *Generative Adversarial Imitation Learning* In Advances in Neural Information Processing Systems, 2016, pp. 4565–4573

实际训练先用当前策略采集轨迹，将专家与策略样本分别标为 1 和 0，通过交叉熵拟合判别器。随后冻结判别器，以 $\tilde{r}_t = -\log(1 - D_{\omega}(s_t, a_t))$ 构造策略优化的奖励：最大化这个负对数项，等价于降低式 (5.3)中的策略判别

项。若两个策略样本分别得到 $D=0.8$ 和 $D=0.2$，奖励约为 1.609 和 0.223，第一项更鼓励模仿专家，却没有证明它满足示范未记录的配送要求。若优化器使用未归一化回报，还要按前文约定换算为 $\widetilde{J}(\pi)=(1-\gamma)^{-1}\mathbb{E}_{d^\pi}\widetilde{R}$，其中 $\widetilde{J}$ 只表示判别奖励的回报。将整个目标乘同一正常数不改变最优策略，但会改变梯度尺度；若只换算奖励项，还必须相应调整正则化权重，才能保留两项之间的取舍。

为了比较当前策略的占用，通常需要继续与环境交互，专家一侧则可以使用固定轨迹。新轨迹采集和判别器、策略的交替优化构成主要成本，判别器过拟合、两份占用支持几乎不交叠或策略更新滞后，都可能妨碍匹配。即使占用相同，也未必满足全部轨迹要求；例如要检查步骤次序，可能需在状态中加入此前步骤的信息。

占用判别并不是从示范学习的唯一入口。若希望避免独立奖励网络与策略网络的对抗更新，可以直接学习软动作价值，即计入动作熵后评价后续回报的 Q。**逆软 Q 学习**（Inverse soft-Q Learning, IQ-Learn）用软 Bellman 关系将奖励与策略都写成同一个 Q 的函数。在有限离散动作、熵温度取 1 时，先对合法动作的指数评分求和再取对数，得到软状态价值，再据此归一化动作概率，并由 Bellman 残差表示隐含奖励：

$$\begin{aligned} V_Q(s) &= \log \sum_a \exp Q(s,a), \\ \pi_Q(a \mid s) &= \exp\{Q(s,a) - V_Q(s)\}, \\ R_Q(s,a) &= Q(s,a) - \gamma \mathbb{E}_{s'|s,a} V_Q(s'). \end{aligned} \tag{5.4}$$

式 (5.4)让一个 Q 同时导出动作分布和隐含奖励。IQ-Learn 的学习目标还用专家转移及选定的分布距离正则项约束 Q，不是对任意 Q 作普通 TD 回归。在线版本可以刷新策略转移，离线版本使用固定专家等转移数据，仍不能越过数据支持的限制；连续动作通常需要参数化行动者近似软策略。减少独立网络的对抗循环，也不意味着 R_Q 已具有唯一的奖励语义[5]。

若我们要解释专家为何选择这些动作，而不只复现行为，就需要约束奖励本身。**逆强化学习**（inverse reinforcement learning, IRL）寻找能够支持专家选择的奖励。Ng 与 Russell 把专家最优性写成奖励约束：已知模型和专家策略时，对每个备选动作要求 $Q_R^{\pi_{\mathrm{E}}}(s,\pi_{\mathrm{E}}(s)) \geq Q_R^{\pi_{\mathrm{E}}}(s,a)$。这表示遵循专家的后续策略时，专家动作不比备选动作差。但零奖励也满足所有不等式，使全部动作并列最优；要缩小候选范围，还需规定奖励函数类、幅度约束或动作价值间隔。专家若只是近似最优，容许误差也必须明示[6]。

无法恢复唯一奖励时，还可以问策略在某一奖励类中是否具有接近专家的回报。学徒学习（apprenticeship learning）采用这一较弱目标，用示范约束长期行为特征。假设奖励为 $R_{\boldsymbol{w}}(s,a)=\boldsymbol{w}^{\top}\boldsymbol{\phi}(s,a)$，其中 $\boldsymbol{\phi}$ 为选定的

[5] D. Garg, S. Chakraborty, C. Cundy, J. Song, M. Geist, S. Ermon, *IQ-Learn: Inverse Soft-Q Learning for Imitation* In Advances in Neural Information Processing Systems, 2021, pp. 4028–4039

[6] A. Y. Ng, S. Russell, *Algorithms for Inverse Reinforcement Learning* In Proceedings of the 17th International Conference on Machine Learning, 2000

状态动作特征，$\boldsymbol{w}$ 为权重。定义归一化特征期望 $\boldsymbol{m}_\pi = \mathbb{E}_{d^\pi}\boldsymbol{\phi}(s,a)$ 后，利用占用与未归一化回报的关系可得

$$J_{\boldsymbol{w}}(\pi) - J_{\boldsymbol{w}}(\pi_{\mathrm{E}}) = \frac{\boldsymbol{w}^{\top}(\boldsymbol{m}_\pi - \boldsymbol{m}_{\mathrm{E}})}{1-\gamma}. \tag{5.5}$$

若权重满足 $\|\boldsymbol{w}\|_2 \le 1$，且两份特征期望的欧氏距离不超过 δ，Cauchy–Schwarz 不等式给出绝对回报差至多 $\delta/(1-\gamma)$。匹配特征因此可以同时控制这类线性奖励的回报差，却无法保证特征未编码的破损要求。计算候选策略的特征期望还需要模型规划或环境采样权限[7]。

[7] P. Abbeel, A. Y. Ng, *Apprenticeship Learning via Inverse Reinforcement Learning* In Proceedings of the 21st International Conference on Machine Learning, 2004

专家也可能在多条可行路线间变化选择，单纯要求一个动作最优不足以描述示范频率。最大熵逆强化学习用轨迹概率模型解释这些变化：较高累计奖励的轨迹取得较大概率，同时保留选择的不确定性。在固定起点、有限时域及确定性动力学的简化设定下，以环境允许的轨迹为候选集合，取

$$p_{\boldsymbol{w}}(\tau) = \frac{\exp\{\boldsymbol{w}^{\top}\boldsymbol{f}(\tau)\}}{Z(\boldsymbol{w})}, \qquad \boldsymbol{f}(\tau) = \sum_t \gamma^t \boldsymbol{\phi}(s_t,a_t).$$

$\boldsymbol{f}(\tau)$ 是整条轨迹的折扣特征和，$Z(\boldsymbol{w})$ 对所有可行轨迹的指数权重求和，使概率归一化。最大化示范平均对数似然，其梯度为 $\mathbb{E}_{\mathcal{D}_{\mathrm{E}}}\boldsymbol{f} - \mathbb{E}_{p_{\boldsymbol{w}}}\boldsymbol{f}$，因此更新增加示范中出现更多、模型中出现更少的特征权重。配分函数和模型期望的计算需要动态规划或采样近似。在随机动力学下，直接给完整未来轨迹加权可能连环境噪声概率也一并改变，而智能体只能选择动作，不能选择噪声。最大因果熵表述据此保留真实转移，只优化依据已有信息可执行的动作分布[8]。

[8] B. D. Ziebart, A. L. Maas, J. A. Bagnell, A. K. Dey, *Maximum Entropy Inverse Reinforcement Learning* In Proceedings of the Twenty-Third AAAI Conference on Artificial Intelligence, 2008, pp. 1433–1438

路线	观测输入	学习对象	输出	所需权限
直接模仿	专家状态动作	条件动作分布	策略	只需静态专家数据，不查询
占用匹配	专家及策略轨迹	占用差异、判别器	策略	通常持续采样环境
软价值学习	专家及可用转移	软 Q 及隐含奖励	价值、策略	离线或在线版本分开
特征期望匹配	示范特征与模型行为	特征期望差	一类奖励下可用的策略	规划或采样候选策略
奖励推断	专家行为与理性模型	奖励参数	奖励候选及对应策略	动态模型或可估计的转移信息

表 5.4 示范学习路线的输入、输出及权限。各方法学习的对象不同；即使算法输出奖励候选，也不表示数据已唯一确定该奖励。

表 5.4应按所求结论来读，而不只按方法名称选择。专家选电梯既可能看重每步能耗低，也可能看重包裹保持水平；两种奖励都支持当前动作，却可能在电梯停运后选择不同替代路线。因此，恢复原环境的可用策略，比恢复可跨环境使用的奖励要求更弱。第 5.4.3节将用未比较路径具体检验这一区别。

5.2.4 从评分与偏好学习奖励或策略

评价者不便给出动作示范时，可能仍能为机器人刚才的行为打分。TAMER 用人工标量反馈拟合评价函数，再按预测评分选择动作。这里拟合的是人的评价，不自动等于环境长期回报；人的反应还有延迟，必须另行判断评分对应哪次动作，不能按按键到达时刻直接归属反馈[9]。

若难以统一“这一段值几分”的尺度，可以让评价者在同一包裹和路线条件下比较两段配送。为了从带噪声的选择记录学习评价函数，我们需要把效用差与选择概率联系起来。令 x, y 为两个片段，$u_\omega(x)$ 为片段效用，$\sigma(z) = (1+\exp(-z))^{-1}$。Bradley–Terry **模型**假定效用差越大，x 胜出的概率越高，并用下式给出具体关系：

$$\mathbb{P}_\omega(x \succ y) = \sigma(u_\omega(x) - u_\omega(y)) \,. \tag{5.6}$$

这种关系是关于比较噪声的可检验假设，不是所有偏好都必然满足的定义。原模型用两个正强度的相对大小表示成对选择概率，将强度取对数，就得到这里的效用差形式[10]。

拟合时，应让实际被选对象取得较大的预测选择概率。用 $b=1$ 记录选 x，用 $b=0$ 记录选 y，并记 $\Delta_j = u_\omega(x_j) - u_\omega(y_j)$。对 n 个条件独立的比较记录，最小化平均负对数似然

$$L_{\mathrm{pref}}(\omega) = -\frac{1}{n}\sum_{j=1}^{n}\left[b_j \log\sigma(\Delta_j) + (1-b_j)\log\sigma(-\Delta_j)\right], \tag{5.7}$$

就能以比较标签更新效用参数。损失对 Δ_j 的导数为 $(\sigma(\Delta_j) - b_j)/n$：预测选择概率低于实际标签时，下降更新会增大相应效用差，反之会减小。给两边效用加同一常数不改变似然，所以这个常数不可由比较识别；若同时拟合噪声温度，效用尺度还可能与温度混淆。

要将片段评价用于逐步决策，还需约定效用怎样从局部奖励组成。一种参数化为 $u_\omega(x) = \sum_{t=0}^{L_x-1}\gamma^t \widehat{R}_\omega(s_t, a_t)$，其中 L_x 为片段长度，片段起点重新编号为 0。这个局部和是附加建模假设，不是成对偏好本身提供的信息。片段长度不同时，比较总量与比较平均质量采用不同标准，改用平均分就改变了效用模型。标注者差异可以用分组或条件变量表示，呈现顺序也应随机化并记录。若稳定偏好形成循环，固定标量效用的严格排序无法表达它；若只是偶尔出现循环标签，则可能是比较噪声。两种情况需分别诊断，不能一律删掉不一致标签。

Deep RL from Human Preferences 将片段比较、奖励拟合和策略更新接成循环：奖励模型为策略提供信号，更新后的策略又产生新的待比较片段。相应的语言模型训练常称为**基于人类反馈的强化学习**（reinforcement learning from human feedback, RLHF），即将人类评价学成奖励，再用它

[9] W. B. Knox, P. Stone, *Interactively Shaping Agents via Human Reinforcement: The TAMER Framework* In Proceedings of the Fifth International Conference on Knowledge Capture, 2009, pp. 9–16

[10] R. A. Bradley, M. E. Terry, *Rank Analysis of Incomplete Block Designs: I. The Method of Paired Comparisons* In Biometrika, 1952, vol. 39, no. 3/4, pp. 324–345

优化生成策略。经典安排先以监督微调取得初始策略，再用偏好拟合奖励模型，随后优化带参考策略约束的奖励，并独立评价新行为。奖励模型拟合准确与策略行为符合要求，是两个需要分别检验的结论[11]。

在语言模型中，完整回答是被评价对象，词元（token）则是每步生成的文本单位，作为策略动作，二者粒度不同。令 q 为输入，$y=(y_0,\dots,y_{T-1})$ 为含结束符的回答，生成前缀构成 $s_t=(q,y_{<t})$，动作是 $a_t=y_t$。这里采用最大长度内自然结束的有限序列，以未折扣总分评价，相当于 $\gamma=1$，不使用无限折扣占用公式；强制截断时的评分及续接规则需要另行规定。奖励模型 $\hat{r}_\omega(q,y)$ 为完整回答输出一个分数，价值模型 $V_\psi(s_t)$ 预测前缀之后的回报，策略 π_θ 逐 token 采样。图 5.3区分这三种计算：一个序列分数可以传播到各步更新，却没有增加逐 token 独立标签。InstructGPT 给出了经典语言模型 RLHF 流程[12]。

为更新这批 token 动作，需要将终局评分与偏离参考策略的代价放入同一回报。冻结当前轮旧策略 $\mu=\pi^{(k)}$、奖励模型和参考策略 π_{ref}，在旧策略样本上构造

$$\tilde{r}_t=\mathbf{1}\{t=T-1\}\hat{r}_\omega(q,y)-\beta\log\frac{\mu(a_t\mid s_t)}{\pi_{\mathrm{ref}}(a_t\mid s_t)}. \tag{5.8}$$

其中 $\beta>0$ 控制参考偏移的惩罚。旧策略和参考策略在各允许前缀的共同合法 token 集合上均须为正，新策略也不能超出该支持。采样对数概率比可以为负；只有在给定前缀并按 μ 对动作取期望时，它才等于非负的前向 KL。按照自然结束时 $V_\psi(s_T)=0$ 的边界条件，计算 $\delta_t=\tilde{r}_t+V_\psi(s_{t+1})-V_\psi(s_t)$ 及 $\widehat{A}_t=\sum_{j=t}^{T-1}\lambda^{j-t}\delta_j$。其中 $0\le\lambda\le1$ 调节未来 TD 误差的权重，$\widehat{A}_t$ 用来判断当前 token 相对基线是否值得增加概率。令 $\varrho_t(\theta)=\pi_\theta(a_t\mid s_t)/\mu(a_t\mid s_t)$，并以 $\epsilon>0$ 指定概率比剪裁范围。PPO 式更新在参数化策略类中最大化下面各回答求和项的样本平均：

$$\sum_{t=0}^{T-1}\min\Big\{\varrho_t\widehat{A}_t,\ \mathrm{clip}(\varrho_t,1-\epsilon,1+\epsilon)\widehat{A}_t\Big\}. \tag{5.9}$$

取两项中的较小值，限制的是样本代理目标对概率比变化的收益，不是为真实策略施加硬概率约束。价值参数另用回报目标回归；本次策略更新将奖励和优势视为固定，下一轮才刷新旧策略与轨迹。参考 KL 也可以放进显式损失，但需使用配套推导，避免在奖励和损失中重复计罚。序列采样、参考概率计算、奖励打分及价值拟合，都是这一安排的计算成本。

逐 token 累加参考代价还会影响长短回答的权重。要把它与完整回答上的 KL 对应起来，可以使用序列概率分解所得的链式法则：

$$\mathrm{KL}(\pi(\cdot\mid q)\|\pi_{\mathrm{ref}}(\cdot\mid q))=\mathbb{E}_\pi\sum_{t<T}\log\frac{\pi(a_t\mid s_t)}{\pi_{\mathrm{ref}}(a_t\mid s_t)}.$$

[11] P. F. Christiano, J. Leike, T. B. Brown, M. Martic, S. Legg, D. Amodei, *Deep Reinforcement Learning from Human Preferences* In Advances in Neural Information Processing Systems 30, 2017, pp. 4299–4307

[12] L. Ouyang, J. Wu, X. Jiang, D. Almeida, C. Wainwright, P. Mishkin, C. Zhang, S. Agarwal, K. Slama, A. Ray, J. Schulman, J. Hilton, F. Kelton, L. Miller, M. Simens, A. Askell, P. Welinder, P. F. Christiano, J. Leike, R. Lowe, *Training Language Models to Follow Instructions with Human Feedback* In Advances in Neural Information Processing Systems, 2022, pp. 27730–27744

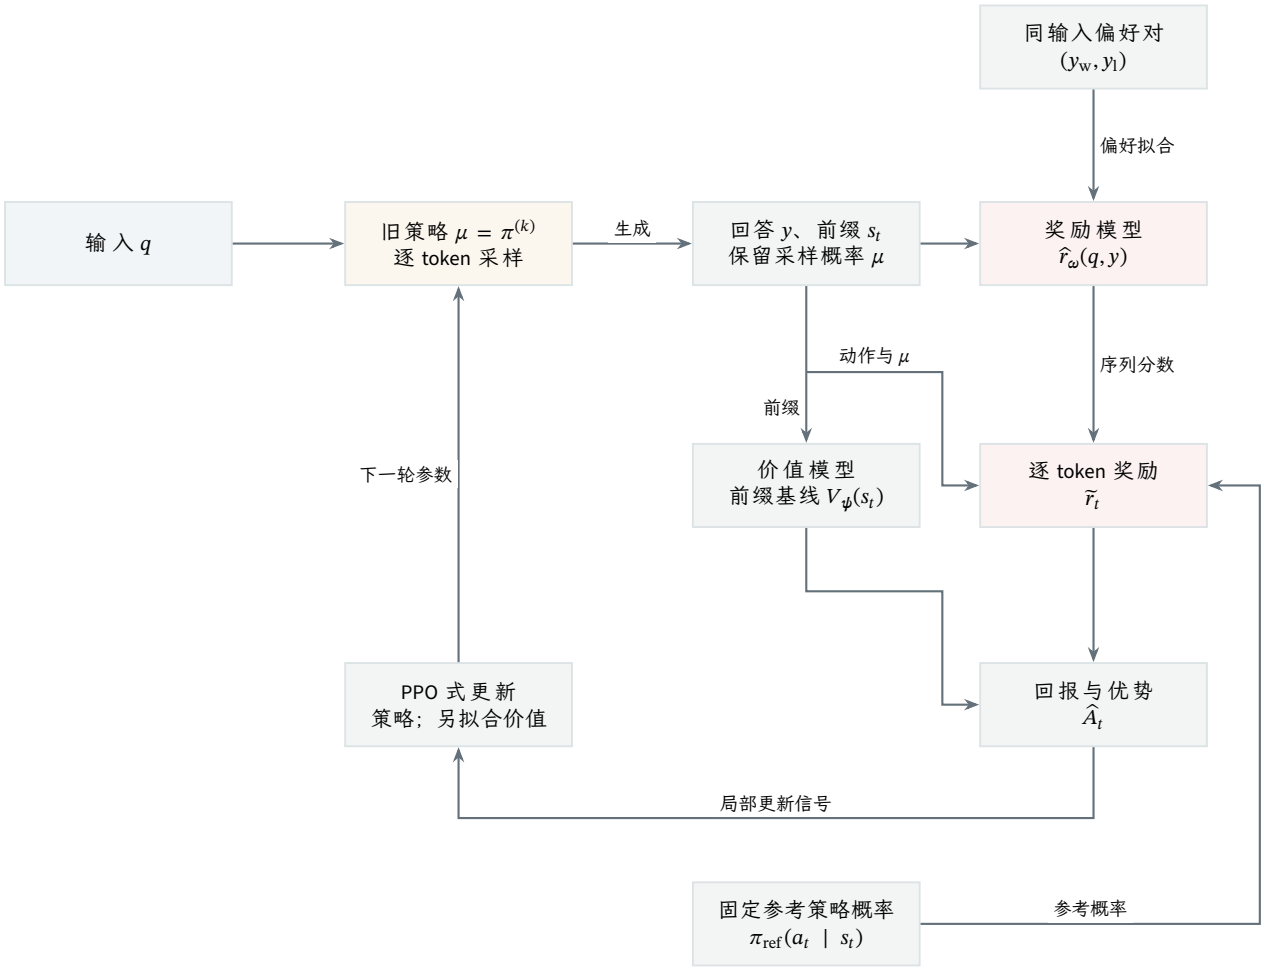


图 5.3 PPO 式 RLHF 中的评价粒度。偏好标签训练完整回答评分器；旧策略逐 token 生成并记录采样概率，价值模型读取前缀提供基线。序列分数、旧策略概率与参考概率按式(5.8)构造逐 token 奖励，再经回报和优势估计进入策略更新；参考偏移不在更新器中重复计罚。图中连线表示数据和训练信号，不表示通过离散采样端到端反向传播。

作为教学例，假设两个回答得分都为 1，长度分别为 2 和 4，各 token 的采样对数比恰好都是 0.1。取 $\beta = 0.5$，扣除参考代价后的样本分数分别为 0.9 和 0.8。差异来自累加项，并不说明奖励模型明确偏好短回答；真实对数比也未必同号或恒定。若将 KL 或策略损失除以长度，就会改变长短回答的相对权重，而不是只做无影响的数值缩放。选择哪种聚合应依据任务标准，不能将一种归一化当成通用答案。

偏好标签不必都由人提供。Constitutional AI 按照明确原则生成批评和修订，结合监督修订与 AI 偏好，再由 AI 偏好学习奖励、优化策略[13]。给定评分函数后，更换评价者不改变优化式的形式，却改变评分依据和误差来源，这些条件将在第 5.2.6节检查。现在先固定奖励 r，考察完整回答的概率分布如何在奖励与参考偏移之间取舍。下面在有限输出集合上优化全部概率分布，以便精确求解；实际网络只允许选择其参数可表示的分布，范围更小。

[13] Y. Bai, S. Kadavath, S. Kundu, A. Askell, J. Kernion, A. Jones, A. Chen, A. Goldie, A. Mirhoseini, C. McKinnon, C. Chen, C. Olsson, C. Olah, D. Hernandez, D. Drain, D. Ganguli, D. Li, E. Tran-Johnson, E. Perez, J. Kerr, J. Mueller, J. Ladish, J. Landau, K. Ndousse, K. Lukosuite, L. Lovitt, M. Sellitto, N. Elhage, N. Schiefer, N. Mercado, N. DasSarma, R. Lasenby, R. Larson, S. Ringer, S. Johnston, S. Kravec, S. El Showk, S. Fort, T. Lanham, T. Telleen-Lawton, T. Conerly, T. Henighan, T. Hume, S. R. Bowman, Z. Hatfield-Dodds, B. Mann, D. Amodei, N. Joseph, S. McCandlish, T. Brown, J. Kaplan, *Constitutional AI: Harmlessness from AI Feedback* In arXiv preprint arXiv:2212.08073, 2022

定理 5.5　KL 正则化奖励最大化的最优策略　固定输入 q，输出集合 $\mathcal{Y}$ 有限，奖励 $r(q,y)$ 有限，参考策略对每个 $y \in \mathcal{Y}$ 均满足 $\pi_{\text{ref}}(y \mid q) > 0$，且 $\beta > 0$。在所有概率分布上最大化

$$F_q(\pi) = \mathbb{E}_{y\sim\pi(\cdot|q)} r(q,y) - \beta\,\mathrm{KL}(\pi(\cdot \mid q) \| \pi_{\text{ref}}(\cdot \mid q))$$

的唯一解为

$$\begin{aligned} \pi^*(y \mid q) &= \frac{\pi_{\text{ref}}(y \mid q)\exp(r(q,y)/\beta)}{Z(q)}, \\ Z(q) &= \sum_{z\in\mathcal{Y}} \pi_{\text{ref}}(z \mid q)\exp(r(q,z)/\beta). \end{aligned} \tag{5.10}$$

证明　有限输出、有限奖励和参考策略的正支持，使 $0 < Z(q) < \infty$，也使候选解 π^* 处处为正。为了比较任意 π 与这个候选解，由定义先将奖励写成 $r(q,y) = \beta\log[\pi^*(y \mid q)/\pi_{\text{ref}}(y \mid q)] + \beta\log Z(q)$。代入 F_q 后，奖励中的概率比与参考 KL 的概率比合并为

$$F_q(\pi) = \beta\log Z(q) - \beta\sum_y \pi(y \mid q)\log\frac{\pi(y \mid q)}{\pi^*(y \mid q)}.$$

第一项不依赖待优化的 π，第二项是减去 β 倍的 KL。由 KL 非负，只有 $\pi = \pi^*$ 时第二项为零，故 π^* 唯一达到最大值。涉及零概率的项按 $0\log 0 = 0$ 连续延拓。 ■

最优解并不把全部概率放在最高分回答上，而是以参考概率为起点，按 $\exp(r/\beta)$ 重新加权。假设两个输出的参考概率都是 $1/2$，奖励为 $(\log 3, 0)$，

$\beta = 1$，则 $Z = 2$，最优概率为 $(3/4, 1/4)$。若参考策略给某输出零概率，任何有限 KL 的策略也必须给它零概率，此时只能在参考支持内优化，不能沿用全输出空间的正支持结论。

这个精确解还提供了另一种偏好拟合方式。假定同一输入的偏好满足以 r 为效用的 Bradley–Terry 模型，便可把奖励差改写为最优策略相对参考策略的对数概率比差：

$$r(q, y_{\mathrm{w}}) - r(q, y_{\mathrm{l}}) = \beta \left[\log \frac{\pi^*(y_{\mathrm{w}} \mid q)}{\pi_{\mathrm{ref}}(y_{\mathrm{w}} \mid q)} - \log \frac{\pi^*(y_{\mathrm{l}} \mid q)}{\pi_{\mathrm{ref}}(y_{\mathrm{l}} \mid q)} \right]. \tag{5.11}$$

其中 y_{w} 和 y_{l} 分别表示胜出和落选回答。同一输入的两边都有 $\beta \log Z(q)$，所以作差后消去；不同输入的归一化常数通常不能抵消。于是可以直接用策略概率比预测偏好，而不单独拟合奖励。以参数化策略替代 π^*，将方括号内的量记为 $z_\theta(q, y_{\mathrm{w}}, y_{\mathrm{l}})$，再最小化胜出标签的负对数似然，就得到**直接偏好优化**（direct preference optimization, DPO）：

$$L_{\mathrm{DPO}}(\theta) = -\mathbb{E}_{(q, y_{\mathrm{w}}, y_{\mathrm{l}}) \sim \mathcal{D}_{\mathrm{pref}}} \log \sigma(\beta z_\theta). \tag{5.12}$$

期望在固定偏好记录 $\mathcal{D}_{\mathrm{pref}}$ 上计算，每条记录含同一输入及其胜出、落选回答。一次更新计算两条完整回答在当前策略和固定参考下的对数概率，再按式 (5.12)下降；这个步骤既不采集新轨迹，也不训练显式价值模型。单条记录的梯度为 $-\beta\sigma(-\beta z_\theta)[\nabla \log \pi_\theta(y_{\mathrm{w}} \mid q) - \nabla \log \pi_\theta(y_{\mathrm{l}} \mid q)]$。沿负梯度更新，局部方向提高胜出回答相对落选回答的对数概率。沿用均匀参考的二输出例，策略 logit 差就是 z；当 $z = 0$ 且 $\beta = 1$ 时，梯度为 $-1/2$，以 0.2 为步长下降后 $z = 0.1$，胜出回答的概率约为 0.525[14]。

显式奖励模型加 PPO，要给新采样回答评分并更新策略；标准 DPO 只在固定偏好对上优化分类式损失，两者使用的数据和学习对象不同。上述换元解释了 DPO 与 KL 正则化最优策略的联系，却没有把 DPO 变成通常意义上的在线强化学习。实际模型类未必能表示 π^*，有限记录未必覆盖所有回答，偏好也未必满足 Bradley–Terry 假设，所以不能由理想关系推出精确恢复最优策略。若在外层反复采样、标注再运行 DPO，便形成迭代式偏好学习；在线访问和新目标信息来自外层协议，不来自分类损失本身。

[14] R. Rafailov, A. Sharma, E. Mitchell, C. D. Manning, S. Ermon, C. Finn, *Direct Preference Optimization: Your Language Model is Secretly a Reward Model* In Advances in Neural Information Processing Systems, 2023, pp. 53728–53741

5.2.5 从过程与结果验证构造策略更新

若任务有明确答案或可执行产物，我们还可以直接检查候选是否满足条件，而不逐对询问偏好。例如运行程序测试、按等价规则比较数学答案，或核对配送签收身份。这些检查可以重复采用同一标准，但它们只能评价实际检查到的条件，不能据此断言整个任务都已正确完成。

定义 5.6 过程反馈与结果反馈 结果反馈（outcome feedback）评价行为结束后的产物或状态，例如答案是否等价、包裹是否正确签收。过程反馈（process feedback）评价中间状态、动作或步骤间关系，例如装载后身份是否一致、推导是否由前提合法推出。可验证奖励（verifiable reward）由明示验证规则产生；其可验证性依赖这条规则、输入前提和检查实现，不表示完整行为目标已经得到验证。

过程与结果提供的证据也不能相互替代。推导可能使用非法除法却偶然得到正确答案，所以结果通过不足以证明过程有效；反过来，每步合法的变换也可能只是在反复改写题目，没有回答问题。表 5.5据检查对象和前提比较验证器，自动检查是否可信仍要逐项判断。

检查器	可检查对象	检查前提	反馈粒度	主要漏检
规则验证器	格式、身份、答案等价	解析与等价规则符合标准	字段、步骤、结果	格式正确但内容错误；解析漏洞
执行器	代码、操作的实际结果	沙箱、测试输入、执行环境有效	工具调用或整次运行	未测试输入、超时与资源副作用
形式检查器	形式命题及证明	形式化忠实，公理和检查内核可信	推理步骤、完整证明	证明了错误形式化的命题
模型评判器	开放式内容与解释	训练覆盖、提示及标准适用	片段、回答	风格偏好、位置偏差、共同模型盲点

表 5.5 四种验证器实际检查的对象及漏检范围。执行测试只支持被测试输入，形式检查只支持所形式化的命题；两者都不能自行证明完整需求已被正确检查。

拿到候选的验证得分后，可以比较同一输入下多个回答，为策略提供相对信号。**组相对策略优化**（group relative policy optimization, GRPO）以这组回答的得分为基准，给高于组均值的回答正信号，给低于均值的回答负信号，从而不必另拟合价值基线。沿用有限序列的未折扣评价，令旧策略 μ 对 q 独立采样 m 个回答 y_i，其验证或奖励模型得分记为 v_i；这里 i 编号候选，不是 r_t 中的动作时刻。为中心化得分并统一组内尺度，定义

$$\bar{v} = \frac{1}{m}\sum_{i=1}^{m} v_i, \qquad s_v = \sqrt{\frac{1}{m}\sum_{i=1}^{m}(v_i - \bar{v})^2}, \qquad \widehat{A}_i = \frac{v_i - \bar{v}}{s_v + \epsilon_{\text{num}}}, \tag{5.13}$$

标准差使用分母 m，$\epsilon_{\text{num}} > 0$ 防止分母为零。结果监督时，同一个 $\widehat{A}_i$ 可以用于回答 i 的全部 token，但它只表示该回答相对本组得分的高低，既不是逐 token 标签，也不是对状态价值函数的估计。

为了将这个组信号接入策略更新，令 T_i 为回答长度，$\varrho_{i,t} = \pi_\theta(y_{i,t} \mid q, y_{i,<t}) / \mu(y_{i,t} \mid q, y_{i,<t})$ 为当前与旧策略的 token 概率比，$\ell_{i,t}^{\text{clip}}$ 为式 (5.9)中

以 $\widehat{A}_i$ 替代 $\widehat{A}_t$ 的剪裁项。一个常见实现先在每个回答内平均 token 项，再在组内平均，并扣除参考偏移代价，最大化代理目标

$$\widehat{\mathcal{L}}_{\mathrm{GRPO}} = \frac{1}{m}\sum_{i=1}^{m}\frac{1}{T_i}\sum_{t=0}^{T_i-1}\left(\ell_{i,t}^{\mathrm{clip}} - \beta k_{i,t}\right), \tag{5.14}$$

其中 $k_{i,t}$ 是所选参考 KL 估计或局部近似，常用形式为 $k = \exp(-\ell) + \ell - 1$，$\ell = \log(\pi_\theta/\pi_{\mathrm{ref}})$；若当前策略和参考策略在同一合法 token 集合上都为正，且动作由 π_θ 采样，那么给定前缀有 $\mathbb{E}_{\pi_\theta}\exp(-\ell) = 1$，从而 k 的期望等于前向 KL。旧策略采样不自动满足这个分布条件；复用旧样本时若没有分布校正，样本平均就不能当成精确 KL，更不能证明硬约束成立。长度平均、剪裁和采样 KL 都属于代理目标的选择，与无近似的期望奖励梯度需要区分。

示例 5.7　一组验证得分的更新信号　假设 $m = 4$，四个得分为 $(1,1,0,0)$，则 $\bar{v} = 0.5$、$s_v = 0.5$。忽略极小稳定项，相对信号为 $(1,1,-1,-1)$。为计算一次更新，再设任务只有一步和两个动作，成功动作概率为 $p = \sigma(z)$，当前 $z = 0$，不加 KL 惩罚，概率比处在未剪裁区。这组样本对 logit 的梯度为

$$\frac{1}{4}\{2(1)(1-p) + 2(-1)(-p)\} = \frac{1}{2}.$$

用 0.2 为步长上升，得到 $z' = 0.1$，成功动作概率约为 0.525。若整组全为 1 或全为 0，中心化后的分子都为 0；稳定项只能使计算有限，不能产生奖励梯度。若实现保留 KL 项，正则化仍可能产生梯度。

上述算例给出的是组内相对信号，不能直接当作无偏真实优势。即使不除以标准差，组均值含样本自身也会改变梯度期望。为了看清这一点，固定 q 和得分函数 v，从 π 独立同分布采样，记 $\boldsymbol{g}_i = \nabla \log \pi(y_i \mid q)$。利用 $\mathbb{E}\boldsymbol{g}_i = 0$，可得

$$\mathbb{E}\left[\frac{1}{m}\sum_i (v_i - \bar{v})\boldsymbol{g}_i\right] = \left(1 - \frac{1}{m}\right)\nabla \mathbb{E}_\pi v.$$

缩放因子来自 $\bar{v}$ 中与 $\boldsymbol{g}_i$ 相关的自身得分，其余独立样本的交叉期望为零。再除以随机 s_v，还会引入与组内成功比例有关的权重；二值奖励混合组中，较少见结果的标准化绝对值更大。改用不含自身的组均值可以消除这个特定缩放，但不能同时消除标准化、剪裁或复用旧样本造成的偏差。

组内比较只要求给出 v_i，并未规定它必须来自规则。DeepSeekMath 提出 GRPO，并讨论结果奖励模型、过程奖励模型和迭代刷新，反馈并不限于规则判分[15]。DeepSeek-R1 原始技术报告中的 R1-Zero 及 R1 推理训练使

[15] Z. Shao, P. Wang, Q. Zhu, R. Xu, J. Song, X. Bi, H. Zhang, M. Zhang, Y. K. Li, Y. Wu, D. Guo, *DeepSeekMath: Pushing the Limits of Mathematical Reasoning in Open Language Models*, 2024, arXiv: 2402.03300

来源或协议	判断依据	相关偏差	可追溯性	查询成本	外部校验
人类反馈	任务知识、个人偏好、指南	疲劳、群体差异、顺序效应	需保留指南与标注群体	人工时间	交叉复核、真实结果
RLAIF	AI 知识与提示中的标准	共享训练偏差、风格偏好	需记录模型和提示版本	推理及抽查成本	独立人评、规则或执行
原则指导反馈	显式原则及其解释	原则遗漏、冲突解释	原则可见不等于执行透明	原则维护与评价成本	逐原则反例测试
模型评判器	学得评分或比较函数	分布外失准、位置与长度偏差	需记录训练数据和模型版本	批量打分与刷新	留出来源、实物或程序检查

表 5.6 反馈来源及协议的判断依据、成本与校验方式。RLAIF 可使用原则指导的模型评判器，因此同一系统可以同时属于多行，不能按互斥类别解读。

用正确性、格式等规则奖励；但 R1 完整多阶段流程还包含监督微调及一般数据上的模型奖励，不能用推理阶段的反馈概括全部训练[16]。

基于可验证奖励的强化学习（reinforcement learning with verifiable rewards, RLVR）说明奖励由明示规则产生，GRPO 则说明拿到分数后如何更新策略，两者不是同一个分类依据。验证器的假阳性、解析偏差、测试泄漏或长度与表达偏好，都可能被策略用来增加得分。增加同一输入的采样数可提供更多组内比较，却不会补齐未检查要求。在多轮工具任务中，还要明确评分针对动作格式、工具执行还是最终完成情况；将终局成功平均分给工具调用，并没有取得独立的动作正确性标签。更长交互的前沿问题见第 1章，语言模型实现由应用卷承接。

[16] DeepSeek-AI, *DeepSeek-R1: Incentivizing Reasoning Capability in LLMs via Reinforcement Learning* In arXiv preprint arXiv:2501.12948v1, 2025

5.2.6 反馈来源与目标可辨识性

回到配送任务，已有示范可能足以复现动作，偏好记录可能足以预测路线胜负，验证器可能足以判断签收身份。要判断目标是否可辨识，必须先指定想要哪种结论，再检查产生同样反馈的候选解释是否都支持它。奖励即使不唯一，候选奖励也可能一致支持当前动作；偏好即使预测准确，也不能说明未被评价的要求已经学会。这正是前章可识别性在目标反馈上的应用。

同一对行为的胜负标签可以由人判断，也可以由模型判断。比较这两种来源，主要要检查判断依据、成本和误差是否相同，而不是仅比较记录格式。形式相同不意味着评价质量相同。

基于 AI 反馈的强化学习（reinforcement learning from AI feedback, RLAIF）由 AI 承担部分评价，再用所得反馈学习策略。**原则指导反馈**（constitutional feedback）则以明确原则指导评价或修订，用这些原则产生批评、修订示范或偏好。前者说明评价来源，后者说明判断依据；原则不是与示范、偏好互斥的记录类型，其选择仍须由外部目标约定。

假设人工标注员和模型都只看终点照片，两者都判断“已送达”，却都看不到包裹内部破损。增加来源一致性没有增加内部状态的信息，因此不能推出包裹完好。来源分歧也未必是噪声：一位收件人看重速度，另一位看重省电，可能确实采用不同取舍，不应直接删除其中一方的反馈。

表 5.6列出的外部校验，也应带上输入和任务范围。评价器只在信息完整的短距离记录上检查过，就不能直接用于长路线、身份缺失或新包裹，并声称同样可靠。现有证据只支持已检验策略在这些输入和标准下的结论；要判断多个奖励解释是否会造成实际失配，还要比较未见行为上的排序。

5.3 奖励归因受限下的强化学习

假设我们已约定配送成功的含义，也能取得相应终局反馈，仍要决定怎样用这个结果更新核对、装载等早期动作。本节暂时固定目标和反馈语义，比较结果回溯、过程判断、奖励变换与辅助目标。这些办法都能为局部决策提供信号，但有的增加信息，有的只改变记账或训练方式，保持原目标所需的条件也不同。

5.3.1 基于长期结果回溯构造局部学习信号

在四步配送中，早期核对决定是否拿对包裹，中间搬运可能只是执行既定方案。REINFORCE 或多步回报能将终局成功用于核对动作的更新，但搬运和提示播放也可能收到同一个成功回报。前章的基线和自举分别减少共同波动、缩短传播路径，并没有直接测量“改变这个动作会使结果变化多少”。这里回用第 3章的估计方法，进一步检查局部信号所表达的贡献。

奖励重分配（reward redistribution）将同一结果重新记到轨迹上的不同位置，使结果与关键事件的时间联系更短。要判断这种记账是否仍优化原目标，必须按原来的折扣权重比较整条轨迹的新旧奖励，而不能只比较未折扣总和。若要求逐轨迹保持回报，应满足

$$\sum_{t=0}^{H-1} \gamma^t \widetilde{r}_t = \sum_{t=0}^{H-1} \gamma^t r_t. \tag{5.15}$$

逐轨迹相等足以保持每个策略的期望回报；也可以使用较弱条件，但需要期望相等对全部待比较策略成立。另要检查信号何时可得。依赖整段历史的新奖励通常不是原状态上的马尔可夫奖励，需要相应表示；若它依赖记账时刻之后才发生的结果，只加入过去历史仍不能使反馈当时可得。

例如 $H = 4$、$\gamma = 0.9$，原奖励 $(0, 0, 0, 1)$ 对应初始回报 $0.9^3 = 0.729$。若全部移至 $t = 0$，新奖励应为 $(0.729, 0, 0, 0)$；若移至 $t = 1$，则应为 $(0, 0.81, 0, 0)$，

两者按折扣计算仍为 0.729。直接移成 $(1,0,0,0)$ 只保留未折扣总和，没有保留原目标。若轨迹长度可变，同样忽略折扣还会改变快慢路径的排序。

保持总回报也不意味着可以直接用新奖励计算 reward-to-go，即从当前动作起的后续奖励回报，包含该动作的奖励。假设终局成败取决于最后一个动作，却将全部结果事后记到 $t=0$，末步的局部回报就变为 0，用它更新末步策略会丢掉该动作的影响。第 3章之所以能删去过去奖励，是因为过去结果不受当前动作影响；事后前移的信号不满足这个因果条件。将不变的完整轨迹回报与整条轨迹的对数概率梯度相乘，仍保留原目标梯度。要改用局部更新，还须另外证明重分配与估计器的配套条件。

一种重分配依据是前缀所提供的结果预测信息。令 m_t 预测看到前缀后的最终回报，将 $m_t - m_{t-1}$ 视为新增预测信息；取 $m_{-1}=0$ 且 $m_{H-1}=G_0$，相邻差求和恰为 G_0。若将其记为折扣局部奖励，且 $0 < \gamma \leq 1$，可取 $\tilde{r}_t = \gamma^{-t}(m_t - m_{t-1})$ 以抵消记账位置的折扣。末端预测不等于真实回报时必须补残差，否则总回报也改变了。实际学习还需控制预测误差和 γ^{-t} 的放大；RUDDER 用回报预测与贡献分析构造信号，其机制入口已在第 3章介绍。

预测信息仍不等于干预贡献。假设正确核对后屏幕总会闪光，日志中闪光与成功高度相关；但关闭闪光不会改变交付，拿错包裹才会导致失败。归因模型只依据相关性时，可能把奖励分给闪光。检验应改变无关标记、受控比较关键动作，并观察实际交付结果；仅有回报预测误差下降不足以证明贡献判断正确。

5.3.2 基于过程反馈构造局部学习信号

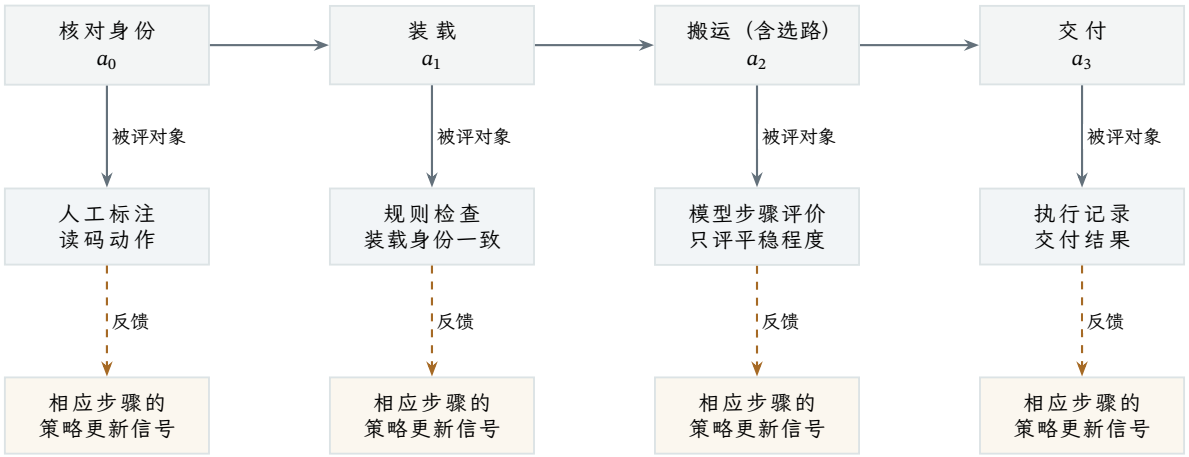
若终局日志无法区分核对错误与中途换包，可以新增装载前的身份检查。这个检查提供新的中间证据，而不是将原总分分摊到各步。需要先明确它评价什么：读码动作、装载后的身份关系和到达时的包裹状态对应不同决策，只有步骤边界和被检关系清楚，才能确定反馈监督的对象。

图 5.4把人工标注、规则检查、执行记录和模型步骤评价放到同一轨迹中，标明各自覆盖的步骤。例如执行记录只证明包裹放入箱内，不证明身份正确；模型觉得搬运平稳，也不能替代破损检查。推理任务中的逐步骤验证是过程监督的一个代表实例，同样需要明确标签标准及标注范围[17]。

即使各处检查都通过，局部正确也可能没有组成全局成功。机器人每次搬运都遵守速度限制、每次放置都平稳，却只在两个中间站往返，没有交给收件人。过程条件没有覆盖最终交付；若各次身份检查只看单个字段，还可能遗漏跨步骤身份一致性。因此，将局部分数求和之前要解释它与整体要求的关系，终局检查不能仅因步骤有标准就取消。

[17] H. Lightman, V. Kosaraju, Y. Burda, H. Edwards, B. Baker, T. Lee, J. Leike, J. Schulman, I. Sutskever, K. Cobbe, *Let's Verify Step by Step* In International Conference on Learning Representations, 2024, pp. 39578–39601

过程反馈也增加获取和维护成本：标注量通常随步骤数增长，不同标注者还可能采用不同的步骤切分。模型反馈若有系统偏差，会在多个位置重复传入更新。可以比较只补关键步骤与标注全部步骤所需成本，统一标准版本，再检查独立交付结果是否改善。若发现检查标准遗漏了要求，就需要修订目标标准，不能只调整局部信号权重。



早期选路没有直接标签，仍靠结果回溯；终局身份与完好要求另行检验

图 5.4 过程反馈缩短部分决策到评价的路径。上方为按时间执行的配送步骤，下方为评价来源；由反馈指向更新对象的虚线表示学习信号。未标注步骤仍依赖终局回报传播，局部通过不取代最终身份和完好检查。

5.3.3 基于奖励变换构造局部学习信号

即使不新增检查，也可以依据已有目标构造即时信号。例如希望鼓励机器人接近终点，但直接给接近动作加分可能使它反复离开再靠近。要避免附加分数任意改变累计目标，可以采用**潜势型奖励塑形**（potential-based reward shaping）：为每个状态设一个评分，按与任务相同的折扣计算相邻评分差，使沿途附加项能够相消。

定义 5.8 潜势型塑形 给定与任务相同的折扣 γ 及状态势函数 $\Phi : \mathcal{S} \to \mathbb{R}$，定义

$$F(s, a, s') = \gamma \Phi(s') - \Phi(s), \qquad r'_t = r_t + \gamma \Phi(s_{t+1}) - \Phi(s_t).$$

Φ 是人为指定或从数据学习的状态评分，称为势函数；附加奖励必须采用这个折扣差形式，不能用任意启发式分数替代。

为判断附加信号是否仍评价原任务，我们比较塑形前后的完整折扣回报。下面利用相邻势项相消，证明在给定条件下两者只差一个不依赖策略的期望常数；这是策略不变奖励变换的经典结论[18]。

[18] A. Y. Ng, D. Harada, S. Russell, *Policy Invariance under Reward Transformations: Theory and Application to Reward Shaping* In Proceedings of the Sixteenth International Conference on Machine Learning, 1999, pp. 278–287

定理 5.9　无限折扣时域的塑形不变性　设 $0 \le \gamma < 1$，Φ 有界，原折扣回报存在且可积，各待比较策略使用相同初始分布 ρ_0。则塑形后的回报满足

$$G'_0 = G_0 - \Phi(s_0), \qquad J'(\pi) = J(\pi) - \mathbb{E}_{\rho_0}\Phi(s_0).$$

因而所有策略在标准期望折扣回报下的排序不变。

证明　先取长度为 H 的有限前缀，以便保留末端边界项。将塑形奖励代入折扣和，相邻势项逐项相消：

$$\begin{aligned}\sum_{t=0}^{H-1}\gamma^t r'_t &= \sum_{t=0}^{H-1}\gamma^t r_t + \sum_{t=0}^{H-1}\left[\gamma^{t+1}\Phi(s_{t+1}) - \gamma^t\Phi(s_t)\right] \\ &= \sum_{t=0}^{H-1}\gamma^t r_t - \Phi(s_0) + \gamma^H\Phi(s_H).\end{aligned}$$

由 $|\Phi(s)| \le M$，末端项绝对值至多为 $\gamma^H M$，当 H 趋于无穷时消失；若 $\gamma = 0$，从 $H \ge 1$ 起该项就为零。因此每条轨迹满足 $G'_0 = G_0 - \Phi(s_0)$。势的有界性保证差值可积，取期望得到只依赖共同初始分布的偏移。任意两策略减去同一个期望数值，其回报差和排序均不变。 ■

保持期望排序不要求 Φ 等于精确价值。即使势函数误将慢路线评为接近终点，只要有界且按同一折扣差加入，定理仍成立；但错误势值可能妨碍学习，使速度或有限样本回报变差。若初始状态随机，$-\Phi(s_0)$ 也是随机偏移，可能改变方差及条件风险价值（CVaR）这类尾部评价，后者关注较差结果中的回报。第 8章的风险目标需要另查不变性，不能继承这里的期望结论。

有限任务没有无穷尾项可供消去，必须保留终端势。允许势随时刻变化，采用 $r'_t = r_t + \gamma\Phi_{t+1}(s_{t+1}) - \Phi_t(s_t)$。沿相同方式展开，可得

$$\sum_{t=0}^{H-1}\gamma^t r'_t = \sum_{t=0}^{H-1}\gamma^t r_t - \Phi_0(s_0) + \gamma^H\Phi_H(s_H). \tag{5.16}$$

这个恒等式也适用于有限时域的 $\gamma = 1$。令 $\Phi_H = 0$ 足以消去末端项；若 H 固定，终端势为所有策略共享的常数也能保持排序。$\gamma = 0$ 时末端项不影响目标，但其他折扣下必须显式处理边界。

自然终止和采样时间截断对应不同边界。自然终止后不再记账时，应将终止势设为零，或显式抵消 $\gamma^T\Phi_T(s_T)$；若 T 可变且 $\gamma < 1$，即便终端势都是同一非零常数，折扣后的末端项也会随长度变化。若采用吸收状态并无限继续记塑形奖励，尾项可以继续相消，但不能只记进入吸收状态的一步，

省略随后塑形项。训练批次截断则可能尚未结束任务，需要保留原续接价值和对应塑形价值 $V'(s) = V(s) - \Phi(s)$；若不保留，就要明示改求有限时域目标。未计算续接价值不意味着它为零。

示例 5.10　遗漏终端势会改变排序　假设 $H = 1$、$\gamma = 0.9$，从同一起点选择到终点甲或乙，原奖励都是 0，且 $\Phi_0(s_0) = 0$。若 $\Phi_1(\text{甲}) = 1$、$\Phi_1(\text{乙}) = 0$，到达后立即停止记账，新回报分别为 0.9 和 0，原本并列的路径变成甲更优。将两个终端势都设为 0 则消除了这一差异；在含中间步骤的任务中，即使中间势不准确，只要满足相应定理条件，仍可保持期望排序。

现在可以具体区分这些保持条件。潜势塑形使共同起点的回报只差固定势值，重分配可以要求逐轨迹折扣回报完全相同，一般辅助奖励则不自动具有这两种性质。即使附加信号更密集、代数上保持了目标，也没有证明它等于动作的因果贡献。

5.3.4 基于辅助目标构造局部学习信号

让机器人预测下一时刻位置，可以用预测误差训练表示，使其保留动力学信息；为每次到达装载区加分，则直接改变策略优化的回报。两者都可提供辅助信号，但前者作用于表示训练，后者作用于行为计分，既不都是新评分，也不都是原回报的等价变换。

为说明更新位置，设共享表示参数为 $\boldsymbol{\eta}$，任务的策略或价值损失为 L_{task}，下一状态预测损失为 L_{aux}。以 λ 设置辅助损失权重、α 为步长，联合更新为 $\boldsymbol{\eta}^{(k+1)} = \boldsymbol{\eta}^{(k)} - \alpha \nabla_{\boldsymbol{\eta}} (L_{\text{task}} + \lambda L_{\text{aux}})$。辅助预测梯度改变共享表示，最终行为仍按原任务回报评价。若改为给动作增加辅助奖励 b_t，采用 $r'_t = r_t + \lambda b_t$，则优化目标变为 $J'(\pi) = J(\pi) + \lambda \mathbb{E}_\pi \sum_t \gamma^t b_t$，除非 b_t 满足额外不变条件，这个新目标不再等于原任务。图 5.5将两条路径分别接到共享表示和回报，显示它们改变的对象。

另外两种训练安排也需区分。训练课程改变任务分布，例如先练短路线，再增加距离；人为子目标改变决策组织，例如先到装载区，再去收件处。二者都不必增加奖励，也不等于潜势塑形。时间抽象回用第 3章；目标重标记及事后经验回放（HER），即将轨迹按实际达到的目标重新使用，由第 6章展开。

若进入装载区就给辅助分，机器人可能反复进出而不交付，因为计分没有限制重复次数，也未要求主任务进展。调整 λ、切换课程或移除辅助信号后，应分别检查原始交付成功、辅助预测误差和子目标完成情况，不能用辅助分的上涨替代主任务收益。表示预测更准确也不证明动作贡献判断正确；共享参数上的辅助梯度还可能与任务梯度冲突。

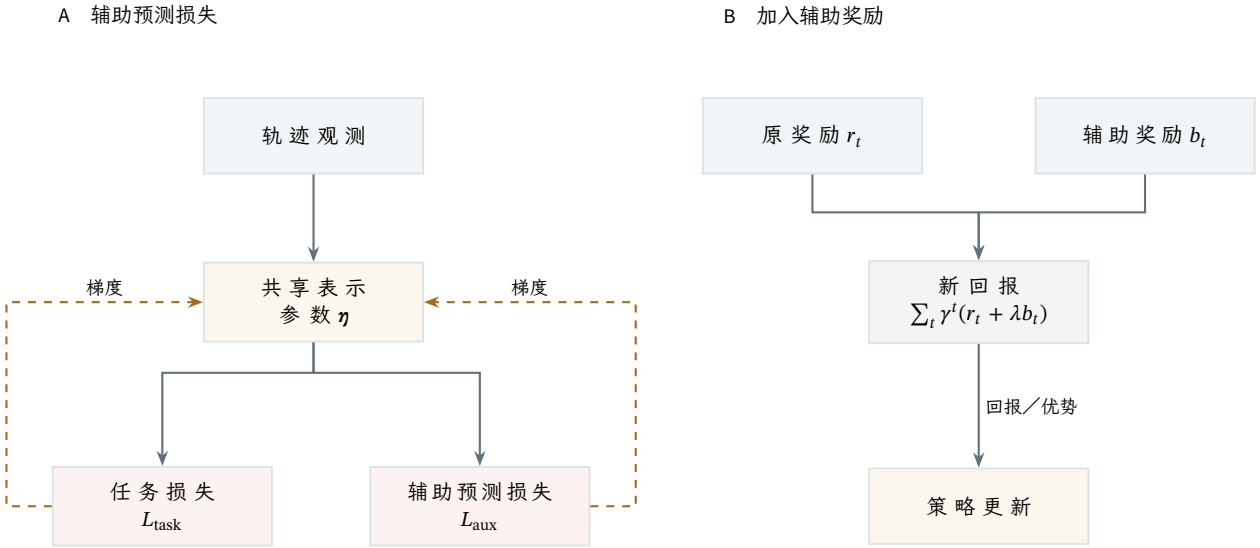


图 5.5 辅助预测损失与辅助奖励的干预位置。左侧虚线为损失对共享表示的梯度；右侧辅助奖励先进入回报，再产生策略更新信号。两种训练的最终行为都应按未掺入辅助分数的原任务标准评价。

5.3.5 奖励归因方法的误差与适用边界

同一终局结果可以回溯记账，可以补充过程检查，也可以与塑形或辅助目标结合。要在这些办法间选择，我们需要比较信息获取成本、局部信号的含义和原目标的保持条件。表 5.7按这几个共同对象对照四条路线。

路线	额外反馈成本	所需轨迹信息	局部信号	原目标保持条件	主要失效
长期结果回溯	可无新标签；需拟合	前缀、终局结果	回报预测变化或重分配	同一折扣下的回报相等，或全策略期望相等	相关标记代替贡献、残差遗漏
过程反馈	关键步骤标注或检查	被评步骤及上下文	局部评分或通过标记	若加入回报，须另证聚合后仍保持原策略排序	局部正确不能组合为成功
奖励变换	势函数构造成本	相邻状态、终止类型	折扣势差	有界势、共同初始分布、正确终端项	截断当终止、折扣不一致
辅助目标	预测标签、额外任务	表示或子任务信息	辅助梯度、额外奖励	预测损失不改评价；额外奖励另证等价	梯度冲突、子目标循环

表 5.7 奖励归因路线的适用条件。过程反馈和一般辅助奖励没有自动保持原目标的代数保证。

即使采用同一条路线，误差也可能来自不同环节。归因模型错误把已经明确的成功结果分给无关动作；有限样本误差使现有证据不足以区分贡献；反馈标准错误则使“成功”本身遗漏破损要求。增加样本可能减轻第二种误差，但不自动修正第一种模型假设，也不会让错误标准变完整。

可以在同一配送任务中固定策略架构与预算，分别检查这些缺口。移除身份过程标签后看身份错误是否重新出现，用来判断中间信息的作用；打乱不影响环境的屏幕闪光，再看局部信号和策略是否改变，用来检测相关性捷径。保持原奖励不变，核查自然终止和时间截断的势值处理，则可排除记账意外改变目标。各项检查都要记录原始交付结果及错误类型，不能只比较掺入辅助分的奖励曲线。通用信用传播仍由前章工具承担，本节补充其信号来源和语义；标准本身的缺口需要转向目标诊断。

5.4 奖励与行为目标不匹配

配送策略可能得到许多反馈，也能将反馈传给早期动作，却仍以高分完成错误交付。此时需要检查计分标准与行为要求的关系。本节按诊断的实际依赖展开：先写清要求和证据，再检测偏差、判断根因，据此修订目标或估计方法。修订后还要用新行为重新检测，更换奖励名称并没有解决偏差。

5.4.1 明确行为目标和代理奖励

配送要求包括交给正确收件人、保持包裹完好，以及满足约定的代价条件，训练代理却可能只给终点图像打分。继续用同一个评分器评价策略，就仍看不到内部破损。表 5.8将每项要求与训练编码、独立证据和未覆盖条件对应；这种逐项检查能显示平均总分可能隐藏的遗漏。

行为要求	训练编码	独立评价	未覆盖条件
交给正确收件人	终点照片评分	签收身份与包裹编号双重核对	照片不含身份时仍缺证据
包裹完好	平稳搬运过程分	独立开箱检查或有效传感记录	隐性破损与传感盲区
能耗可接受	电量成本或偏好权重	校准电表、同负载路线比较	新载荷、不同电池状态
按时交付	终局成功或到达时间分	固定截止时间下的完成记录	长尾延迟与未完成轨迹

表 5.8 先建立行为要求到证据的对应，再选择数值聚合。某项无法观测意味着结论受限，不意味着它可以从目标中消失。

完整记录要求也不意味着所有要求都能同时改善。例如高收益配送可能更耗电，单一总分已经替决策者选定了取舍。向量奖励保留各项目标的数值，再另行指定怎样比较它们，使权衡不被藏在总分中。

定义 5.11 向量奖励、标量化与 Pareto 最优 令 $\boldsymbol{r}_t = (r_{t,1}, \dots, r_{t,d})^{\top}$ 记录 d 个目标，期望回报向量为 $\boldsymbol{J}(\pi) = \mathbb{E}_{\pi} \sum_t \gamma^t \boldsymbol{r}_t$。标量化（scalarization）用给定函数把多个目标转成一个数值，例如以 $\boldsymbol{w}^{\top}\boldsymbol{J}(\pi)$ 比较策略，其中 $\boldsymbol{w} \geq 0$ 规定各目标的权重。在指定策略类 Π 中，若不存在 $\pi' \in \Pi$ 使每个目标都满足 $J_j(\pi') \geq J_j(\pi)$ 且至少一个严格大于，则称 π 为Pareto 最优（Pareto optimal）。也就是说，在这组候选中，改善某个目标必

> 须牺牲至少一个其他目标。所有分量约定为越大越好，能耗可用负能耗表示。

图 5.6采用四个教学候选：甲 $(2,4)$、乙 $(4,7)$、丙 $(6,8)$、丁 $(5,5)$，横、纵坐标分别为能耗和收益，所以向左上改善。乙比丁收益高且能耗低，因而支配丁；甲、乙、丙在这四个候选中没有被支配。若按“收益减能耗”比较，三者得分为 2、3、2，就选择乙。改变策略类，例如允许随机混合，会改变可达集合及候选前沿。若标量化非线性，还需规定先取回报期望再变换，还是先变换随机回报再取期望，两种次序一般不等价。多目标策略集的求解可作延伸阅读[19]。

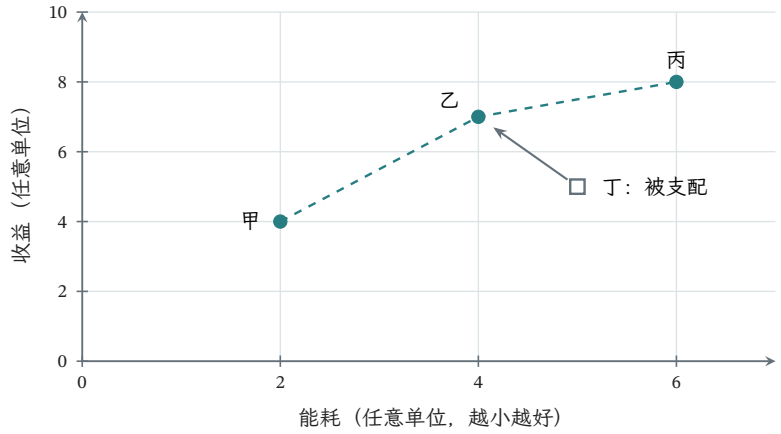


图 5.6　收益越大、能耗越小越好。实心点是在四个教学候选策略中的非支配点，空心方块丁被乙支配；虚线只帮助识别候选前沿，不断言连线上的策略全部可实现。

据此可以区分几种看似相近的安排。预先给定偏好后求一个策略，与保留多个非支配策略供以后选择，求解的输出不同；多个来源都估计“完好交付”，则仍是同一目标的多份证据。若规定能耗必须低于上限，能耗成为不可任意用收益补偿的约束，而不只是加权分数。约束求解与执行保护由第 8章展开。

5.4.2　检测行为与代理奖励的偏差

用配送代理给行为打分以前，要先检查代理是否遗漏了已知要求；策略更新以后，还要检查新行为是否超出原反馈覆盖。两种检查都需要在优化前固定独立指标、留出反馈来源和必要情形。例如按路线长度、身份信息完整性与包裹类型分层，可以主动检查训练成功轨迹中少见的情况，只从常见成功轨迹抽样则可能继续漏掉它们。

图 5.7用解析曲线演示一种待检测现象：代理分数一直上升，按独立标准衡量的行为可能先改善再恶化。两条曲线的差别提醒我们同时查看训练

代理和任务证据，不说明所有训练都会遵循这个形状。真实比较还需报告指标口径、采样预算、误差范围与模型选择过程。Gao 等研究了奖励模型过度优化的经验现象，本图仍是教学示意，不是该论文的测量结果[20]。

不同测试可以针对不同缺口。反例测试检查已有怀疑，例如照片看似送达但身份错误；压力测试增加路线长度、载荷或重复次数，考察长时交互及极端输入。对抗测试主动寻找骗过代理的行为，例如展示别人的签收码；人工审查则分析难以形式化的失败。每次都应记录具体输入、行为、分数和验证器版本，使失败可以复查，不能只留下汇总总分。

如果依据留出结果调整奖励或挑选策略，这批证据就参与了开发。下一轮要补充新的独立检查，或明确报告测试复用范围，不能继续把旧结果当作完全未见数据上的验证。即使没有发现偏差，结论也只适用于已测情形，不能证明所有未见行为均满足要求。

[20] L. Gao, J. Schulman, J. Hilton, *Scaling Laws for Reward Model Overoptimization* In Proceedings of the 40th International Conference on Machine Learning, 2023, pp. 10835–10866

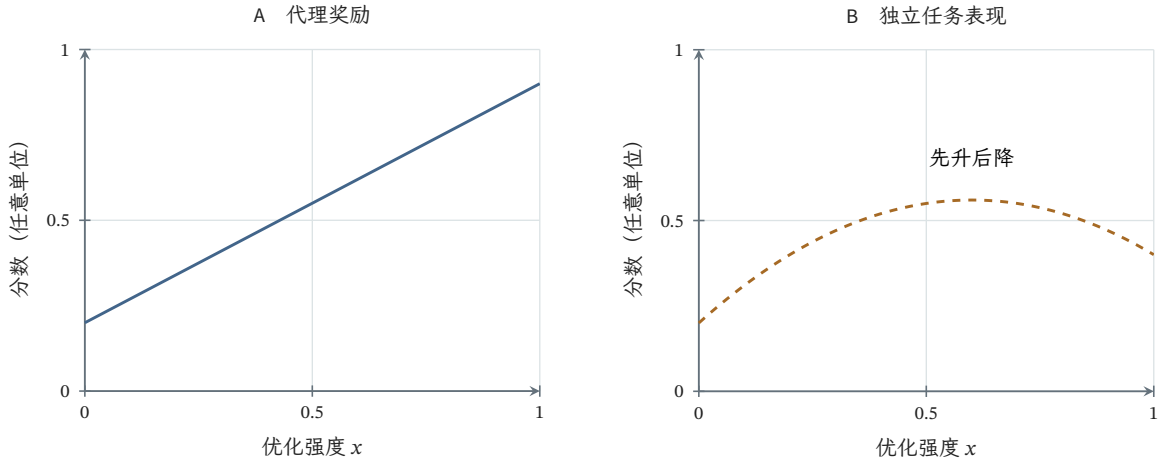


图 5.7 代理与独立表现可能分离的双面板示意。横轴 $x \in [0,1]$ 是归一化优化强度，曲线分别由 $p(x) = 0.2 + 0.7x$ 与 $b(x) = 0.2 + 1.2x - x^2$ 构造，纵轴为任意单位；不是实验结果，也不表示固定的普遍动力学。

5.4.3 区分奖励歧义与行为目标偏差

两个奖励都解释配送示范时，我们要继续问它们在哪些行为上等价。第 5.3.3节的势差在边界条件满足时保持所有策略的标准期望回报排序，只改变表示；另一些奖励却只在已见示范上相容，在未见路径上作出不同选择。后者限制目标外推，但要认定当前行为失配，仍需比较该行为与独立要求。

示例 5.12 示范相容不等于新路径等价 假设训练环境只允许专家路径 E 和路径 B，两个终局奖励都给它们 $(2,0)$，于是都支持专家选择 E。测试环境关闭 E，另开放此前不可行且未经专家比较的 C,D。R_1 给 (C,D) 的分数为 $(1,-1)$，R_2 给 $(-1,1)$，而两者仍给 B 记 0 分。因此训练环境中所有可行选择的分数相同，测试时却分别选择 C 和 D。即使再重复收集一万次训练选择，新增记录仍不涉及 C,D，不能区分两种目标解释。

在这个例子里，原环境可用的策略可以确定，跨环境重用的奖励却不能确定。恢复原策略、解释专家奖励和恢复可迁移奖励，是强度不同的结论，第三种还要支持新选择的排序。若新状态始终没有反馈，训练得到唯一参数解也可能只是正则化或模型结构替我们作了选择，而不是数据识别了唯一答案。

要尝试跨环境重用奖励，一种办法是分开任务计分与依赖原环境的价值信息。**对抗逆强化学习**（adversarial inverse reinforcement learning, AIRL）为此将奖励项和塑形项分别参数化，再用专家与策略转移训练判别器。例如采用

$$D(s,a,s') = \frac{\exp f(s,a,s')}{\exp f(s,a,s') + \pi(a \mid s)}, \qquad f(s,a,s') = g(s,a) + \gamma h(s') - h(s). \tag{5.17}$$

其中 g 表示待恢复的奖励项，h 表示状态上的塑形评分，f 组合两者。专家和新策略转移用于拟合判别器，策略再依据判别信号更新；迁移时希望重用 g，而不是整个 f。这一分解的可迁移解释有条件：原论文的恢复分析依赖状态奖励、确定性动态、相应状态连通条件、最大熵专家及理想优化等假设。一般状态动作奖励、随机动态或有限次优示范，不会仅因写出这个分解就获得无条件恢复保证[21]。

[21] J. Fu, K. Luo, S. Levine, *Learning Robust Rewards with Adversarial Inverse Reinforcement Learning* In International Conference on Learning Representations, 2018

这并不意味着所有势差一换环境就失效。若保留依赖实际转移的形式

$$R(s,a,s') + \gamma\Phi(s') - \Phi(s),$$

并用新环境实际后继重新计算势差，满足原边界等条件时仍可相消。若先在旧环境对后继势取期望，保存成固定状态动作奖励 $R(s,a)+\gamma\mathbb{E}_{P_{\text{old}}}\Phi(s')-\Phi(s)$，再直接用于新动态，旧转移期望通常不再与新轨迹上的相邻势值相消。AIRL 试图区分的正是与旧动态及专家行为纠缠的部分；可否迁移需检查实际奖励形式，不能将失败归于势差本身。

表 5.9将信息不足、标准遗漏、分布外误差和漏洞利用分开，后两者还可能相互强化。**奖励投机**（reward hacking）是策略利用代理缺陷取得高分，却违反原行为要求；**过度优化**（overoptimization）是继续加强代理优化时，独立目标可能转而恶化。更新改变行为分布，代理在新区域评分出

根因	可观察症状	不能仅凭什么判断	补充验证
代理定义遗漏	高分行为违反未编码要求	训练集评分准确率	要求到证据审计、针对遗漏的反例
目标信息不充分	多个相容奖励在新行为上分歧	奖励参数不唯一	有区分力的专家选择或偏好查询
反馈模型分布外误差	新策略行为评分与独立评价不符	旧分布拟合误差小	新行为重标、覆盖与校准检查
优化器利用漏洞	更新后反复产生某种虚假高分行为	单次异常或代理单独上涨	固定漏洞复现、版本对照、修补后再测

表 5.9 同一种行为偏差可能来自多个根因。奖励歧义本身不等于目标错误，唯一拟合也不能证明标准正确。

错，优化又偏向虚假高分行为，就可能形成这种反馈。不过分布外误差未必已被利用，奖励不唯一也未必造成错误行为，仍要用具体反例和独立要求作判断。

5.4.4 修订行为目标并约束策略更新

发现高分配送有问题后，需要按根因选择修订对象。新增“内部完好”要求，是补充原目标；为同一完好标准补充标签说明，是修订操作性标注规则。重训评分器改进对既定标准的估计，修补允许空字符串通过的验证器则修正实现。四种改动影响不同，必须保留目标、标注、验证器和策略版本，不能统称为奖励模型升级。

修订以后若仍有估计误差，可以惩罚可估计的模型不确定性，用多个奖励模型的分歧定位缺口，或限制策略更新幅度。这些措施各有边界：模型可能共享盲点，不确定性估计也可能失准；保守更新减少进入未见区域的速度，同时可能压低原本可获得的收益。KL 约束只控制相对参考策略的偏移，不能补回参考策略已遗漏的要求，平均 KL 小也不保证每个罕见状态都不变。

新增数据应回答已经发现的缺口。例如旧签收照片骗过代理时，可以补充照片与当前包裹身份的一致性检查，再收集不同伪造变体。模型刷新后重测原反例，并检查未参与修补的新变体，才能判断修订是否扩大了正确覆盖。比较时还要记录独立任务指标的变化、采用保守更新后减少的任务收益以及新增反馈成本，不能只报告旧训练集拟合改善。

图 5.8显示不同修订如何返回检测：目标改动要重新明确要求，估计或实现改动要重新检验新行为。关闭一个反例不表示其他要求都已满足；风险、约束违反和运行时保护还需要第 8章的工具。

5.5 三类奖励限制叠加时的反馈学习

同一配送训练可能同时只有少量示范、部分路线偏好、过程记录和不完备的验证器。我们将这些材料接成一轮可复查的学习过程：明确本轮要求和

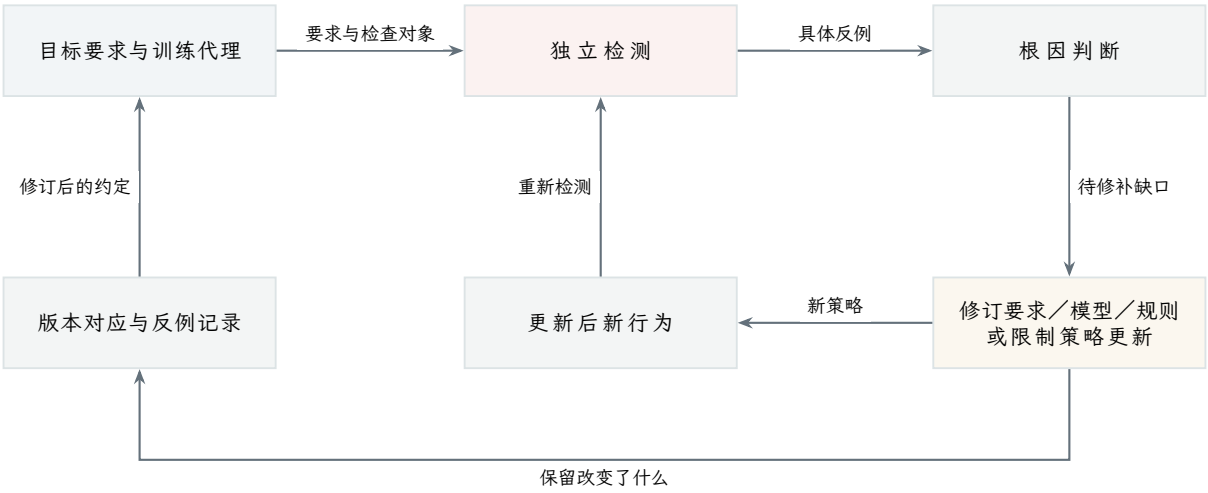


图 5.8　目标与代理的诊断回路。检测传递具体反例，根因判断决定改变要求、修订估计还是限制更新；修订后的策略产生新行为，必须重新接受独立检测。

反馈用途，更新有依据的模型或策略，再独立检验新行为，决定停止或补充信息。这里才有实际轮次的先后依赖；三类限制提供不同诊断依据，并不要求每轮依次消除它们。若反馈始终没有涉及某项要求，迭代也不能自行解除目标歧义。

5.5.1　整合已有反馈形成当前反馈约束

将配送示范、偏好和检查记录放在一起以前，需要知道它们各自在评价什么。一条可用记录至少包含任务输入、被评价行为、反馈值和形式、来源、采样策略及标准版本。轨迹评分还要记录步骤范围和终止原因，偏好还要保留两个候选及呈现顺序。这些字段使我们能够区分冲突来自行为条件、评分尺度还是标准变化。

这里用“反馈约束”概括记录对候选行为和评价模型提供的限制，但实施时必须分开三件事。行为要求规定什么算完成任务，例如交给正确收件人；训练目标规定怎样利用记录拟合模型，例如动作负对数似然和偏好比较损失。策略更新限制则规定本轮允许多大偏移，或排除哪些行为。带噪偏好通常进入损失，不是每条都必须满足的硬不等式；身份要求若作为硬约束，还要有可检查条件和可靠执行机制。

表 5.10按记录、约束对象和本轮用途整合配送反馈。同一数据可以支持多个模型，但动作标签、相对排序和正确性判断的语义不同，在说明聚合依据前不能直接相加成总分。

假设专家走楼梯，偏好却选择电梯。先比较包裹是否易碎、当时电梯是否可用、评价者是否强调节能；只有条件和标准相同时，才需要进一步判断来源可靠性或专家是否次优。装载检查通过而终局身份失败，也可能来

反馈记录	约束对象	可靠范围	冲突处理	本轮用途
专家装载动作	条件动作分布	指令完整的已见状态	检查隐含指令与次优示范	行为克隆初始化或局部纠正
同包裹路线偏好	相对效用	同一偏好群体与标准	保留来源分层，不强行平均	拟合路线效用差
装载身份检查	步骤关系正确性	可读编号且检查器有效	与终点身份联合复核	提供局部信号
签收验证	最终身份条件	签收记录可信	排除旧记录与解析漏洞	终局反馈；另留独立样本
少量完好评分	包裹状态评价	评分尺度一致	复核尺度与开箱依据	校准反馈模型
独立开箱审查	未覆盖要求的证据	被抽查任务范围	不用于本轮拟合	检查代理遗漏

表 5.10 同一轮反馈记录的五项对应。独立证据应按样本和用途隔离，不能一边参与拟合一边称为留出检验。

自中途换包，局部标签各自都正确，但跨步骤一致性被破坏。保留条件和粒度才能定位这些差异，平均正负分反而可能掩盖原因。

整合后，本轮要输出明确的要求、训练目标和更新限制。例如先要求身份正确，再在满足身份条件的行为中比较完好与能耗；用动作示范拟合策略，用路线偏好和完好评分分别拟合比较模型及评分模型。策略更新还可以采用参考 KL 惩罚或约束，但必须说明是哪一种。身份优先的文字约定并没有自动提供动作过滤器，硬性执行能力仍要验证。所有约定都应附上适用输入范围及尚未解决的分歧。

若分歧确实来自不能兼容的真实偏好，可以保留按偏好条件选择的策略或多个候选。必须聚合时，应解释分数单位、尺度、权重及权重代表的取舍；加权平均是一个新约定，不是争议已经被识别为唯一真实目标的证据。

5.5.2 依据反馈约束联合更新模型与策略

已有反馈及其用途确定后，要明确本轮改动哪些学习对象。对应记录可用于拟合奖励、效用或通过概率模型，归因机制再把轨迹结果转成局部信号，策略在本轮惩罚或约束下利用这些信号更新，并产生下一批行为。价值基线帮助降低方差或自举，不替代已经约定的行为评价标准。“联合更新”可以是交替拟合，也可以只改其中一项，不要求全部参数同时反向传播。图 5.9标明数据依赖，以及本轮冻结的标准和参考策略。

在这条更新路径中，反馈来源和优化器是两个选择。RLHF 与 RLAIF 可以采用相同策略优化器而使用不同评价者；迭代式偏好优化可以每轮补新偏好，再运行 DPO；在线 RLVR 则对当前策略样本即时调用规则验证。表 5.11比较各轮更新和固定的对象，以及样本和反馈何时刷新，而不是将这些名称当成互斥算法类别。

表中的 DAPO 指 Decoupled Clip and Dynamic sAmpling Policy Optimization，其修改集中在剪裁、样本筛选和损失聚合。它在所讨论训练

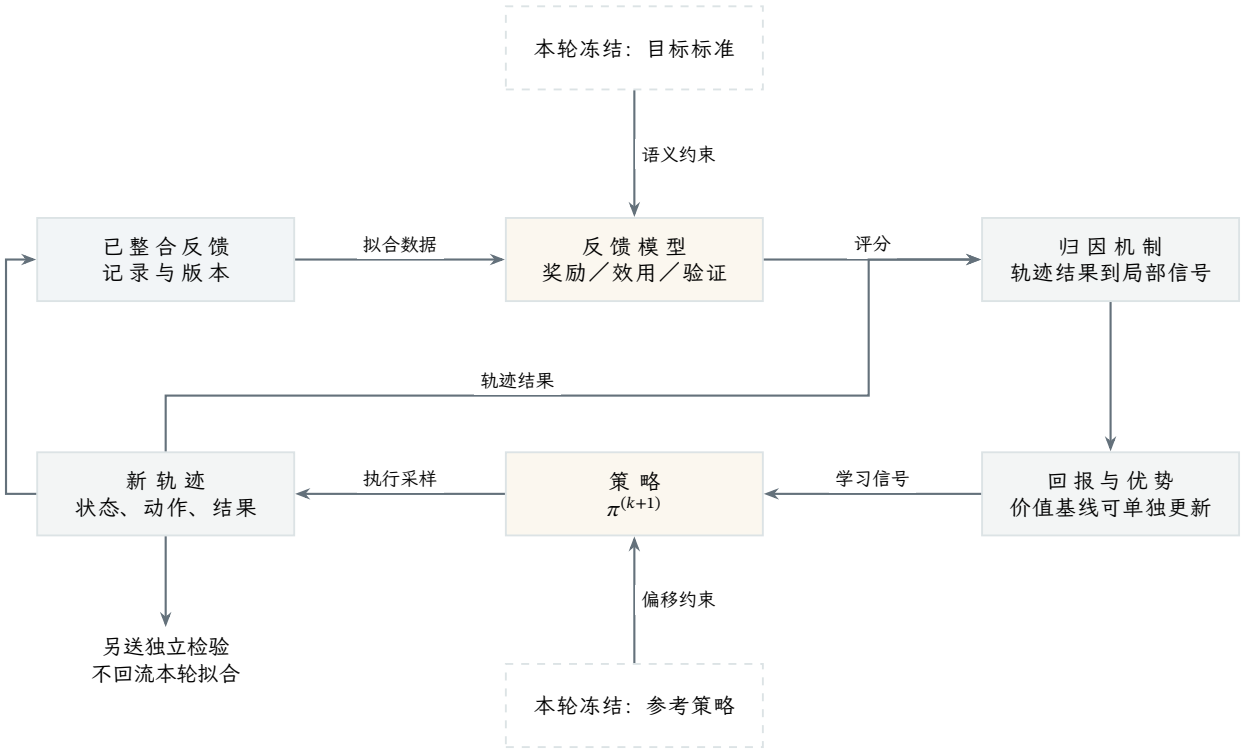


图 5.9 一轮模型与策略更新的数据依赖。反馈记录约束反馈模型，轨迹结果经归因机制形成局部信号，策略产生下一批轨迹；虚线边界表示本轮冻结的目标标准和参考策略。检验数据不沿训练箭头进入拟合。

路线	本轮更新对象	本轮固定对象	采样与反馈刷新
PPO 式 RLHF	奖励模型、策略及价值可分阶段更新	标注标准、参考策略；策略阶段冻结奖励	当前策略采样，按预算补人类偏好
RLAIF	反馈模型与策略，依实现可有价值模型	AI 评价模型、提示与标准的指定版本	新样本交由 AI 评价，独立抽查
迭代式偏好优化	偏好对上的策略参数	单轮偏好集与参考策略	外层采样和标注刷新，内层可离线 DPO
在线 RLVR	策略；基线依更新器而定	验证规则、答案或测试集	新策略候选逐批验证
DAPO	无独立评论家的策略更新	当前验证规则、旧策略批次概率	动态采样补充混合得分组，按 token 聚合损失

表 5.11 反馈闭环而非互斥算法分类。DAPO 是在线可验证反馈的一种具体实现，RLAIF 也可以组合不同的策略优化器。

设置中使用规则结果奖励，去掉参考 KL 项，采用不同的上下剪裁阈值，并动态补充组内同时有成功和失败的输入。损失还从式 (5.14)的回答内平均，改为对全部有效 token 平均。为比较长度权重，记剪裁项为 $\ell_{i,t}$，两种聚合是

$$\frac{1}{m}\sum_i \frac{1}{T_i}\sum_t \ell_{i,t}, \qquad \frac{1}{\sum_i T_i}\sum_i\sum_t \ell_{i,t}. \tag{5.18}$$

前者赋予每个回答相同总权重，后者赋予每个 token 相同权重，使长回答在整批损失中占更大总权重。超长惩罚与截断处理也会改变反馈语义；论文称之为 reward shaping，不意味着满足本章的潜势型不变条件。DAPO 发表于 NeurIPS 2025，但经验结果只对应报告中的模型、数学任务和预算，不能推出这些组件对所有任务都有收益[22]。

动态采样补混合得分组，可以减少零相对信号，但筛选也改变训练输入分布，被丢弃候选仍消耗采样和验证预算。过滤整组失败的困难题，没有解决这些题。提高剪裁上界只是改变代理目标梯度何时饱和，不是对动作概率施加硬上限。因而比较实现时，应同时记录样本选择、组内标准差分母、长度聚合方式和验证器版本。

示例 5.13　一轮可复查的更新记录　假设教学轮次 $k = 3$ 使用数据 $D3$、身份与完好标准 $S2$、反馈模型 $M3$、旧策略 $P3$ 和参考策略 $P0$。$D3$ 有 20 条装载动作、12 对偏好、8 条完好评分，分别用于策略拟合、比较模型拟合和评分模型拟合，后两项组成 $M3$。策略更新时冻结 $S2, M3, P0$，独立审查记录不加入 $D3$。

再取两条等长四步轨迹，以本轮约定的综合代理 $\widetilde{R}$ 给终局记 1 和 0 分，中间奖励为零，$\gamma = 0.9$，于是起点回报为 0.729 和 0。冻结基线为 0.3645，减去基线得到样本优势 0.3645 和 -0.3645。只更新起点二动作的 logit，其他动作规则固定；初始 logit 为 0，两条轨迹各来自一个起点动作，样本平均梯度为 0.18225。令步长为 0.2、KL 系数为 0.1，且当前策略恰与参考相同，精确 KL 梯度此时为零。一次未剪裁更新得到 logit 0.03645，正优势动作概率约为 0.5091，作为候选 $P4$。

本轮记录目标为“轨迹代理回报的 PPO 式改进减参考 KL”，并分别预留 40 个访问状态动作标签、20 对比较、100 次验证和 10 次人工审查的预算上限。更新后要分开检验 $M3$ 是否更符合反馈和 $P4$ 是否改善实际行为。这些计算是可复查的教学记录，不是实测性能。

5.5.3 用更新后行为检验反馈约束的有效性

候选 $P4$ 产生新行为后，要按本轮开始前的标准检查，不能只重算 $P3$ 的旧日志分数。三类限制分别对应三个问题：新状态是否超出反馈覆盖，局部信号是否仍正确联系关键动作与结果，代理回报增加时独立行为指标是否

[22] Q. Yu, Z. Zhang, R. Zhu, Y. Yuan, X. Zuo, Y. Yue, W. Dai, T. Fan, G. Liu, J. Liu, L. Liu, X. Liu, H. Lin, Z. Lin, B. Ma, G. Sheng, Y. Tong, C. Zhang, M. Zhang, R. Zhang, W. Zhang, H. Zhu, J. Zhu, J. Chen, J. Chen, C. Wang, H. Yu, Y. Song, X. Wei, H. Zhou, J. Liu, W.-Y. Ma, Y.-Q. Zhang, L. Yan, Y. Wu, M. Wang, *DAPO: An Open-Source LLM Reinforcement Learning System at Scale* In Advances in Neural Information Processing Systems, 2025, pp. 113222–113244

改善。表 5.12分列相应证据和失效判据，使一种检查通过不能替代其他检查。

检查	输入行为	独立证据	失效判据	仍未覆盖范围
观测与覆盖	新策略访问状态、长短轨迹	新状态专家标签、留出来源评分	无支持区域仍被赋予高置信评价	未采到的输入和动作
局部归因	关键步骤与相关标记	受控扰动、过程复核、终局结果	无关标记改变信号，关键错误不受罚	不可干预步骤的因果贡献
目标匹配	代理高分的新行为	独立身份、完好和成本检查	违反已约定要求或独立指标退化	未形式化与难观测要求
来源一致性	同行为的多来源判断	第三方执行或事实核对	分歧无法由条件差异解释	一致来源的共同盲点

表 5.12 检验必须说明未覆盖范围。来源一致性可以暴露冲突，却不能替代外部事实证据。

检验结果应区分证据支持、证据不足和明确失效。若 $P4$ 在预定短路线、身份可读范围内完成全部检查，估计精度也达到事先要求，可以支持当前反馈在这个范围有效。若只测三次且均成功，仍未覆盖必要长路线或满足精度要求，就只能说暂未发现失败。若已有代理高分却交错收件人的行为，便得到明确反例；平均成功率高不能抹去这个失效。

诊断要返回对应缺口：新状态无标签就补访问覆盖，关键步骤局部信号错误就修订归因，完好要求未编码就修订标准或代理。这样可以针对已有证据改变相关对象，不必一次失败就重训全部模型。反例若进入下一轮修订，就成为开发数据，后续不能再将它单独称为独立留出检验。

5.5.4 依据检验结果与反馈预算决定停止或继续

即使新行为全部通过已做检查，也需要判断检查是否达到了事先约定的要求。训练前应固定独立指标的接受标准、必要覆盖、统计精度或不确定性要求，以及各类预算上限，不能看到结果后再放宽门槛。有限测试可以支持限定范围的接受，不为未测范围提供“没有失败”的保证。

证据状态	允许的后续动作	必须保留的结论范围	所需信息
达到预设充分性与接受标准	停止训练，保留复核入口	只接受已测任务、标准和策略版本	已完成覆盖、精度及成本记录
未发现失败但证据不足	有预算则定向查询；否则停止或收窄范围	未证实原范围满足要求；预算停止不等于成功	缺少的场景、样本或独立来源
已发现明确失效	暂停对该范围的接受，修订后再测；或终止	记录反例与不适用范围	根因、修补方案、验证与查询成本

表 5.13 停止训练是一种行动，接受行为是一个证据结论，二者不能混同。

表 5.13区分停止行动和接受结论。满足预设要求可以停止，预算耗尽也可以停止，但后者仍可能留有关键缺口。若获准查询只能看终点照片，不能观察包裹内部，重复评价也无法识别完好要求；这时应收窄结论或改变信息接口，而不是将次数当作充分性。

有剩余预算时，还要说明下一批反馈可能改善哪项判断：当前状态覆盖、候选目标排序、过程贡献或验证规则。可以估计查询减少多少候选模型分歧、是否可能改变决策，再与人工时间、采样和执行成本比较；没有校准数据时，这些只是启发式依据，不是有数值保证的信息价值。更换目标、反馈标准或明显改变策略访问分布后，原停止证据所对应的对象也变了，需要重新检查。

算法 5.2 反馈学习的继续与停止闭环

输入： 目标标准、独立接受条件、必要覆盖、分项预算、初始反馈与策略
输出： 候选策略、结论范围、停止原因和未解决缺口

while 尚未记录停止原因 **do**
    整合兼容的反馈，固定本轮标准、数据范围及未解决分歧
    只更新有相应证据支持的反馈模型、归因机制或策略
    以新行为接受独立检查，分类为充分、证据不足或明确失效
    if 覆盖与精度充分，且满足预设接受条件 **then**
        记录“在已检验范围满足要求”，停止本轮学习
    else if 预算不足，或允许查询不能区分关键目标解释 **then**
        记录“预算停止”或“识别受限”，收窄结论并停止
    else
        按观测、归因或目标缺口选查询，必要时先修订目标标准
        获取新反馈，记录成本、生成策略与标准版本，返回整合
    end if
end while

算法 5.2只更新有相应证据支持的对象，不要求每轮全部模型变化。明确失效可能先需要修订要求，而不是马上增加样本；若获准查询无法补足缺口，也可以停止优化错误代理，并保留未解决结论。这个规则控制反馈学习是否继续，不替代系统部署审批或运行流程。

5.5.5 针对反馈缺口获取新反馈

决定继续后，还需把未决问题转成可执行查询。例如错误走廊缺恢复动作，就查询该状态上的专家标签；两条新路线排序不定，就比较候选奖励意见不同的路线。表 5.14按这类缺口列出查询能排除的解释，同时保留查询之后仍未回答的部分。

查询的选择依据也不同。DAgger 查询当前访问状态的专家动作，主动偏好查询选择可能改变候选排序的比较；不确定性采样选择反馈模型分歧大的行为，在线验证检查当前策略产物，对抗收集则寻找代理漏洞。但模型分歧不必等于真实目标信息量：共同盲点可能让模型一致自信，模糊措辞却可能造成很大分歧而不改变行为要求。保留独立随机或分层抽查，可以检查主动筛选是否遗漏重要区域。

具体缺口	查询方式	可以排除的解释	仍不能回答什么
偏离后不会恢复	当前访问状态上的专家动作	这些状态上的错误动作候选	唯一真实奖励与未查询状态
新路径排序不确定	比较奖励候选意见不同的路径	对该比较给出相反排序的目标	其他输入或群体的偏好
关键过程贡献不清	步骤标注、受控检查与结果对照	局部无效却被奖励的归因	未控制混杂下的完整因果结构
验证标准遗漏	新结果检查、规则边界与对抗案例	会接受已知错误行为的验证器	未被形式化的全部要求
来源共同偏差	独立来源和实际执行审查	仅依赖共同代理的解释	未审查行为的真实性

表 5.14 查询应增加能区分候选解释的信息，而不只是重复已经一致的反馈。

沿示例 5.13，假设 $P4$ 主要缺恢复动作，可以查询 6 个实际访问状态的动作；为新路线再补 4 对偏好、24 次验证和 2 次人工审查。还要分别记录取得候选所用轨迹数及环境步数。这些教学计数单位不同，相加成“36 条反馈”不能说明成本；每批记录应附带生成策略 $P4$、标准 $S2$ 及采样筛选协议。

新反馈返回第 5.5.1节时，先核对与旧标准的兼容性。沿用 $S2$ 的记录可聚合；若 $S3$ 新增内部破损要求，旧终点照片标签只支持原先被检查的条件，需视用途重标或分开使用，不能直接当作 $S3$ 的完整正例。若全部获准查询只比较速度，就仍无法区分看重完好和看重能耗的目标解释。此时应报告识别边界，闭环轮数没有提供缺失的信息。

5.6 本章小结

回到配送中的反馈缺口，替代记录首先决定我们能学到什么。示范约束动作或长期占用，评分和偏好约束评价函数，验证只判断明示条件；它们不相互等价，也不必都先还原为唯一奖励。BC 在已有专家分布上拟合，DAgger 补当前访问状态；奖励模型加策略优化需要评分新行为，标准 DPO 拟合固定偏好对。GRPO 怎样比较组内候选，则与分数是否来自规则是两个选择。

取得结果以后，还要判断它怎样支持早期动作更新。结果回溯重新记账，过程监督增加证据，奖励变换和辅助目标改变信号或训练位置，各有成本与保持条件。潜势塑形在有界势、共同初始分布及正确终端处理下，靠相邻势项相消保持标准期望回报排序；这不证明局部信号具有因果意义，也不保证风险排序或学习速度不变。

最后，训练信号是否表达行为要求，必须由独立证据检查。对全部策略保持排序的奖励变换只改变表示；只解释同一批反馈的候选奖励却可能在未比较行为上分歧。拟合成功不证明标准完整，奖励歧义也不必妨碍选择当前范围内的可用策略。反馈学习能否继续改进，取决于每轮是否明确固定标准、更新对象、检验证据和新增信息；停止时还要区分满足限定要求、

预算耗尽和识别受限。更密集反馈、更大模型或更多轮次，都不能代替这些判断。

第 6 章

任务泛化与适应

一辆已经学会绕过障碍的小车，换一个终点还需要从头试错吗？如果地图不变而地面变滑，旧的转向习惯还能直接使用吗？这两个问题看似都在问“能否迁移”，所需保留的知识却不同：更换目标通常不必重新认识动作的物理效果，改变移动规律却会使原先的到达概率失效。即使任务确实共享结构，智能体也未必知道新任务是哪一种，更未必获准通过试错弄清它。

第 3 章已经建立单个任务中的价值、策略与模型学习。本章增加任务之间的关系：先确定变化范围、可用信息与预算，再判断哪些知识可以保留、它们适用于哪些目标任务。训练阶段形成这些知识，部署阶段则依据描述、历史和更新权限形成具体策略。图 6.1 把这几项职责分开；其中的验证反馈意味着失败可能要求修改共享假设，而不仅是增加训练次数。涉及历史充分性与固定日志时，分别调用第 4 章的信念与覆盖条件；反馈含义仍由第 5 章的目标规定。

6.1 任务泛化与适应问题

6.1.1 任务要素的变化范围

沿用前文宽 4、高 3、障碍位于 $(2,2)$ 的导航地图，起点仍为 $(1,1)$。基准任务以 $(4,3)$ 为终点，合法意图方向以 0.8 概率执行，两侧各以 0.1 概率滑移；进入终点得 1，其他非终止步得 -0.04，吸收后奖励为 0，折扣为 $\gamma = 0.9$。这些是统一的教学设定，不是实测数据。现在分别改变终点、移动噪声、观测符号或动作编码，检查哪些数学分量随之改变。旧策略可能依次错在“去哪里”“动作会到哪里”“眼前是什么”和“命令代表什么”，而不只是遇到了不同的数据文件。

定义 6.1　任务族　用任务参数 $c \in \mathcal{C}$ 索引环境

$$\mathcal{M}_c = (\mathcal{S}_c, \mathcal{A}_c, P_c, R_c, O_c, \rho_{0,c}, \gamma).$$

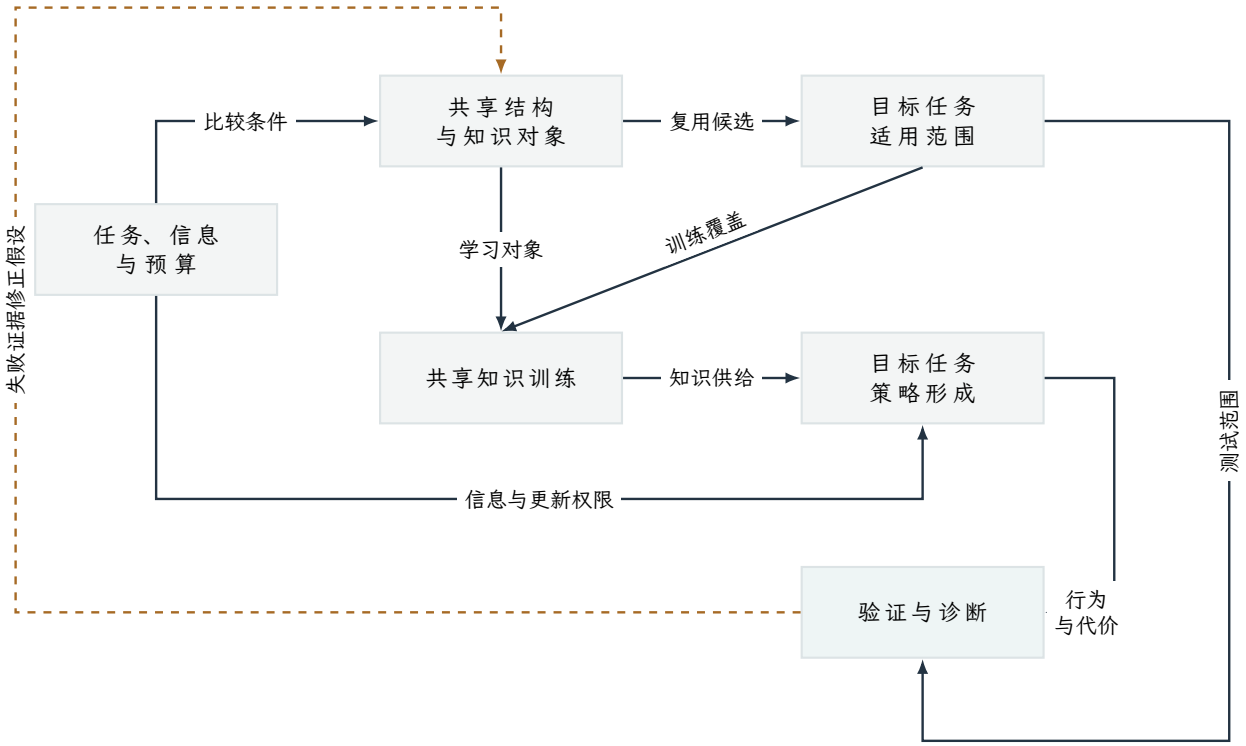


图 6.1 任务泛化与适应的论证关系。实线标明条件约束或知识供给，虚线表示验证后的修订反馈；不是所有方法都必须顺序执行的流程。部署中的记忆、参数更新和持续交互可以组合。图为本章关系的原创示意。

> 其中 O_c 为观测核，$R_c(s,a)$ 为动作时刻奖励的条件期望。任务族是这些环境及其任务信息接口的集合。比较时须声明哪些分量随 c 改变，哪些共同固定；有终止事件或有限时域时，还须规定终止机制与时域。

同一状态集合上的两个奖励函数已经定义了不同任务；状态和动作的维数相同，并不要求转移、奖励或语义相同。若要根据随机奖励和终止反馈辨识任务，还须给出这些反馈与后继状态的联合条件分布：均值 R_c 本身不能确定反馈似然。表 6.1 列出四种单因素变体，其中可直接观察的信息由实验协议提供，不是把智能体训练中见过的信息一概当作已知。

这里有一个容易遗漏的细节：如果“终点”意味着进入后吸收，那么换终点不仅换奖励，也改变哪些状态可以继续移动。需要严格隔离奖励变化时，本章会显式改用共同终止规则：例如所有任务在相同时间结束，或使用固定的吸收出口、只改变沿途地标的奖励。前一种有限时域设定还须把剩余时间纳入状态，才能用同一个转移核表示终止机制。这些是为检验复用条件而定义的独立变体，不是基准网格的另一种数值解。

还要区分两个时间尺度。在一次适应试验中，未知风向可以固定不变，只是智能体逐渐认识它；也可以每个回合都改变。前者的证据指向同一估

变化分量	保持不变的对象	可直接观察的信息	需要重算或重新学习的对象
终点与奖励	地图、物理移动规律	可能提供目标坐标；也可能只有到达反馈	新目标价值、路线选择；终止规则改变时还包括有效转移
移动噪声	目标含义、地图、命令语义	位置与移动结果；风参数未必给出	转移概率、长期后果、控制策略
观测符号	潜在地图与物理动作	新符号图像；对应表可能未知	感知对齐，必要时重学历史表示
左右命令互换	物理空间、目标、观测	命令标签与执行结果	动作映射、合法命令集与技能接口

表 6.1 同一导航地图中的任务变化。每行单独改变一个因素，数字与任务均为教学构造。更换吸收终点会改变完整 MDP 的转移核，不能只因物理移动规则相同就声称共同动力学。

计对象，后者的旧证据可能已经过时。固定任务辨识在第 6.5.5 节展开，变化任务的跟踪在第 6.5.6 节另行定义。

6.1.2 目标任务信息的可用条件

终点标在地图上时，小车可以立即规划；终点隐藏、抵达才发奖励时，它必须从反馈中排除候选位置；风向隐藏时，即使终点已知，也可能要试一次移动才能分辨转移规律。目标是否变化与任务身份是否可见是两个问题。已知新目标不等于已知新动力学，未知任务也不等于没有任何先验。

显式任务描述（explicit task description）是执行前提供的目标坐标、参数或语言指令，其作用是直接约束任务含义。**历史任务信息**是由已记录的观测、动作、奖励与终止标记推断的任务信息。**主动辨识**（active identification）则通过选择动作获得更有区分力的反馈；它改变了未来可用的信息，而不仅是对已有历史多计算几遍。语言描述只有在其与奖励和控制接口的对应关系成立时才有用，不能把一句自然语言自动当作完整 MDP。

设训练任务用编号 1 和 2 分别代表东、西两个终点。把编号交换、保留所有轨迹的物理内容，再相应交换训练标签，并不会改变问题难度。对于从未出现的编号 3，训练记录没有告诉模型它是北端终点还是强风任务。编号能索引记住的任务，却没有坐标那样的几何语义。新编号上的零样本迁移必须另有描述映射，不能依靠编号的大小顺序。

历史编码器输出的向量 $\boldsymbol{z}_t$ 同样只是一个计算结果。若它经过奖励预测或策略损失训练，可以包含有用的任务信息，但不自动满足后验概率的归一化与校准含义。更根本地，若所有获准动作在两个任务中都产生相同的反馈分布，再长的历史和再大的模型也不能凭空区分任务。第 6.5.1 节会把这种信息缺口与推断近似误差分开。

6.1.3 零样本、少样本与持续适应预算

“不更新网络”并不是完整的预算说明。一个网络可以保持权重不变，却在上下文中读过大量目标任务反馈；另一个网络可能在固定日志上更新参

协议	目标交互	可见反馈	上下文	参数更新	额外计算	选模查询
零样本	无适应步；执行另计	描述、执行观测	不累计任务学习信息	0	固定推理预算	0
固定日志适应	新交互 0	日志给定字段	至多 L 步	至多 K 步	推断与反传均计	预先固定
少量在线适应	总计 B 步	约定奖励及终止	至多 L 步	至多 K 步	探测、规划均计	纳入 B
持续在线适应	全程累计	按到达时刻可见	记忆重置规则固定	频率与总量均报	每步和累计成本	不用未来成绩选模

表 6.2 目标任务预算的不同分量。各列共同定义协议；“固定日志”与“固定参数”不是同义词。本表为评价口径，不是算法性能数据。

数，却没有权限增加一次真实交互。为比较两者，需要分别记录数据、可变状态和计算。

本章将**零样本执行**（zero-shot execution）限定为不使用目标任务反馈进行额外学习、记忆适应或模型选择的执行。它仍可读取给定任务描述和正常控制所需的观测。部分可观测任务中的状态滤波应预先声明：在已给定任务模型下估计当前位置，属于控制所需的状态估计；利用偏移反馈推断未知风向，则改变了任务信息，属于适应，即使只发生在一个回合内、网络权重始终不变。**少样本适应**（few-shot adaptation）使用预定数量的目标经验形成策略；经验可以来自给定日志，也可以来自获准交互。**持续适应**（continual adaptation）允许在部署过程中反复更新任务信息或策略，评价必须计入这一过程中的表现。

表 6.2 用教学协议固定这些差别。B 表示适应交互步数，L 表示最多保留的历史长度，K 表示梯度步数；实际论文还应报告各回合长度，不能仅以“若干回合”比较不同任务。

假设每回合恰有 20 步，共运行 10 回合，这是教学预算而非实测配置。只报告第 1 回合、按固定控制规则响应观测且不辨识任务或更新策略，回答的是初始执行能力；允许在 10 回合内学习并报告全部 200 步回报，回答的是学习期间能否付得起试错成本；先适应 10 回合，再停止任务学习、另测 5 回合，回答的是 200 步适应后的控制能力，但总交互已是 300 步。三种分数即使相等，也没有相同含义。

试探风向、从失败位置恢复、查询检查点成绩都消耗目标任务资源。选择“最好的第 7 次更新”需要看目标任务结果，不能只报告最终执行的步数。预算的完整性决定了“快”的比较对象。

6.2 可复用决策知识的确定

6.2.1 由任务要素异同判断共享结构

只换导航目标时，旧地图仍能回答向右会走到哪里；把左右命令互换时，地图虽然相同，原策略发出的“右”却执行向左。直接复制参数是否可行，取决于参数所计算的对象，而不取决于网络能否接受同样形状的张量。图 6.2 用逐分量矩阵显示这种区别。



共同终止规则；P 按物理动作索引。
A_c 表示命令到物理动作的映射。

图 6.2　导航任务族的要素矩阵。相同符号与底纹表示同一分量，斜线及新符号表示变化；“换目标”行使用共同终止规则。$f_r(s,a,s')$ 表示给定转移后的计分规则，换目标时改为 $f_{r,g}$；换噪声保留 f_r，却可能改变均值奖励 $R_c(s,a)$。P 按物理动作索引，命令交换由 A_c 表示；若按命令标签索引，转移核也须相应变换。矩阵为控制变量设计，不表示从数据证明了共享关系。

共享结构（shared structure）是关于任务对象的可检查假设。例如，在统一状态动作语义下 $P_c = P$；奖励都由同一组特征线性组合；观测可以映射到同一控制充分状态；或技能在各任务中具有同样的启动集与终止含义。这些假设强弱不同，不能统称为“任务相似”后省略。

实验者编写的任务生成器可以保证某个模块不变，此时结构是已知的。若从多任务轨迹估计共同转移，再通过留出数据检验，则结构是估计结果，带有覆盖与误差条件。仅因两条学习曲线相似而猜测可以共享，只是待检验假设。控制变量比较应在相同状态、相同物理动作及相同反馈定义上检查差别；否则观测编码错误可能被误诊为动力学变化。

相似特征与相似回报都只能提供线索。一个编码器可能把两个外观相近、却需要相反动作的状态合并；两项任务也可能恰好在当前策略访问的区域一致，而在未访问区域完全不同。共同结构的声明必须带上适用状态动作范围。

复用对象	共享条件	目标任务仍需估计的量	典型失效
状态表示	保留目标控制所需信息；观测可对齐	任务特定变量、价值或策略	丢掉新目标需要的线索
环境模型	相同转移机制或已知模块关系	风向、摩擦等特定参数	未建模机制改变
奖励特征	特征语义不变，新奖励可表示	新权重 $\boldsymbol{w}_c$	新目标不在特征类中
后继表示与特征	固定策略、动力学和折扣	新奖励权重；必要时补新策略	转移变化或策略库覆盖差
价值函数	原价值对应目标奖励、转移与策略	不满足条件时需重估价值	旧数值仍可算但含义已错
策略初始化	接口兼容，少量更新有合适方向	目标任务参数修正	小数据噪声导致负适应
技能	启动、输入、动作效果和终止兼容	高层选择、组合或内部适应	能启动却不能达到所需效果

表 6.3 可复用知识及其条件。共享条件说明对象何时有意义，不承诺有限数据训练能够满足这些条件。来源为本章定义与后文推导的归纳。

6.2.2 由共享结构确定可复用知识

共享关系确定后，才有理由选择保留什么。转移模型描述给定状态和动作后的变化规律，因此动作的物理效果不变时，它可能继续适用。价值函数评价的是在特定动力学与奖励下遵循某份策略的长期回报；只更换奖励，也可能需要重算价值。策略则根据可用信息选择动作：即使它在新任务中仍能正常运行，也要检查这些动作能否实现新目标。判断复用范围，需要逐项核对所保存的预测或决策规则依赖哪些任务条件。

例如，把终点从 $(1, 3)$ 换到 $(4, 1)$，可保留物理地图与动作效果，但到旧终点的距离和价值不能直接解释新任务。把滑移概率由基准的 0.2 改成教学假设 0.4，目标坐标仍有相同含义，但旧到达概率必须重新估计。表 6.3 将复用对象与所需条件成对列出。

技能是具有持续时间的行为，而不是一个固定长度动作数组。即使“绕过障碍”技能仍能运行，新任务也可能要求中途停在障碍旁；此时技能的终止语义不合适。检查启动集、输入、控制效果与终止条件，比仅运行一次确认“没有报错”更接近决策层面的兼容性。时间抽象的单任务定义见第 3 章，本章关心这些条件如何跨任务保持。

6.3 可复用决策知识的适用任务

同一个复用对象可以在不同目标任务上成立或失效。本节固定候选对象，分别检验任务生成关系、奖励、动力学以及观测动作接口；这些是并列的检查视角，可以同时作用于一个任务。

6.3.1 训练任务与目标任务的生成关系

从一张已知地图随机抽取更多轨迹，与从多种目标和风参数中抽取新任务，是两层不同的采样。用 $p_{\text{训练}}(c)$ 表示训练任务总体分布，$p_{\text{目标}}(c)$ 表示所声明部署范围的任务分布。给定任务 c 后，轨迹还服从由 P_c、初始分布和收集策略共同决定的分布 $p_c^{\mu}(\tau)$。因此训练平均至少包含

$$\mathbb{E}_{c\sim p_{\text{训练}}}\mathbb{E}_{\tau\sim p_c^{\mu}}[\ell(c,\tau)].$$

外层变动任务，内层变动同任务中的经历；大量内层样本不能替代外层任务多样性。

有限任务清单 $\{c_1,\dots,c_n\}$ 只给出了实际训练对象。任务生成器是可继续采样新对象的程序，其采样规则定义一个分布。理论中的总体分布则可能是对部署环境的假设，并不一定有可运行生成器。使用经验分布 $n^{-1}\sum_i \delta_{c_i}$ 时应明确它只在已见任务上有质量，不能把这个支持集与假设总体的支持混用。

上下文 MDP（contextual MDP）用 c 控制一个 MDP 的分量；这里的“上下文”指任务条件，未必是网络的历史窗口。物理状态与 c 都可见时，策略可以写为 $\pi(a\mid s,c)$。物理状态可见、c 隐藏但在适应期间固定时，s_t 加上任务后验 $b_t(c)$ 形成**贝叶斯自适应 MDP**（Bayes-adaptive MDP）的状态：动作既影响位置，也影响对任务的认识。状态也隐藏时则需联合信念，具体更新见第 6.5.1 节。

图 6.3 给出一组教学任务划分。横轴为地图上边界目标 $(x,3)$ 的横坐标，纵轴为总滑移概率 η。训练总体仅允许 $x\in\{1,2,3\}$，其中 $x=3$ 只与 $\eta\le 0.2$ 组合；$x=1,2$ 允许 $0\le\eta\le 0.4$。抽到一个未见的 $(1,0.15)$ 仍属于同分布新任务；$(2,0.2)$ 可检验已见噪声值之间的插值；$(3,0.3)$ 的两个因素各自出现过，却在联合支持之外；$(4,0.45)$ 则含未见因素范围。

这里“未见”相对于有限样本，“支持外”相对于声明的总体，二者不是同义词。若原总体本来就独立抽取目标与噪声，$(3,0.3)$ 可能只是在训练清单中缺席，而不在总体支持之外。组合测试必须说明所依据的是边缘支持、联合支持还是经验清单。

6.3.2 目标与奖励变化下的可复用知识

保持地图与移动规律不变，把目标从左上角移到右下角，重新规划不必从头估计每条物理转移。但旧价值把未来访问按旧目标计分，不能只改名字继续使用。若希望不重新展开每条轨迹就评价新奖励，需要保留尚未加权的长期后果。

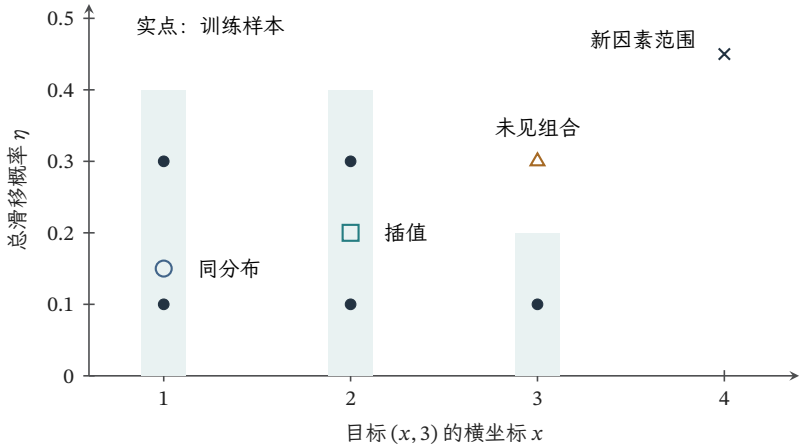


图 6.3 目标位置与移动噪声的教学任务平面。竖向浅带表示离散目标坐标下的总体噪声支持，实点为有限训练样本，其他点形区分留出任务类型。插值只沿噪声轴解释，不把离散网格目标当成连续位置；所有点与支持范围均为教学设定。

设所有任务有共同 $\mathcal{S}, \mathcal{A}, P, \gamma$ 以及一致的观测、动作和终止语义。将转移条件下的期望奖励写成

$$R_c(s,a,s') = \langle \boldsymbol{\phi}(s,a,s'), \boldsymbol{w}_c \rangle, \qquad \boldsymbol{\phi}, \boldsymbol{w}_c \in \mathbb{R}^d. \tag{6.1}$$

这里 $R_c(s,a) = \mathbb{E}_{s' \sim P(\cdot|s,a)} R_c(s,a,s')$，没有把奖励样本 r_t 当成已知期望。共同的 $\boldsymbol{\phi}$ 记录“经过了哪些地标、付出了多少步成本”等事件，$\boldsymbol{w}_c$ 规定新任务怎样评价这些事件。

在固定策略下，保存未来各特征的期望折扣总量，就能用新权重重新计分。这一对象称为**后继特征**（successor features, SF）。对于教学路径，若前两步分别出现 $\boldsymbol{\phi}_0 = (1,0)^\top$、$\boldsymbol{\phi}_1 = (0,1)^\top$，之后特征为 0，那么 $\gamma = 0.9$ 时后继特征为 $(1, 0.9)^\top$；权重 $(2,-1)^\top$ 给出价值 1.1，换为 $(0,3)^\top$ 则给出 2.7。变化的是评价标准，而不是路径分布。

共同终止规则在这里不可省略。若新目标一到达就吸收，路径分布也随之改变，旧后继特征不能自动表示新任务。可改用固定吸收出口、仅改变经过地标的奖励，或重新学习包含新终止机制的后继特征。第 6.4.4 节会完整推导价值分解，并讨论如何从多条已有策略中逐状态选择动作。原始后继特征框架正是针对共同动力学下的奖励迁移[1]。

即使新奖励可表示，策略库也可能没有掌握通往新目标的行为。保存了正确的后果表示，只能评价已有行为及其可用组合，不等于已经拥有新任务的最优行为。

[1] A. Barreto, W. Dabney, R. Munos, J. J. Hunt, T. Schaul, H. van Hasselt, D. Silver, *Successor Features for Transfer in Reinforcement Learning* In Advances in Neural Information Processing Systems, 2017

6.3.3 动力学变化下的可复用知识

固定终点，只把可靠移动改成受风影响的随机移动，进入终点得 1 的含义没有变，但选择一条窄路的长期后果会变。动力学复用应区分模型结构与模型参数。若风参数 η 已提供，而且模型族 P_η 正确，可以代入新参数重新规划；若 η 未知但只是一维参数，则可能只需辨识它，而不必独立估计每个状态动作的全部后继概率。

例如，在没有边界或障碍干扰的指定测试位置，教学模型令移动偏离意图的指示量为 $X_j \sim \mathrm{Bernoulli}(\eta)$。独立重置采样 n 次时，估计 $\hat{\eta} = n^{-1}\sum_j X_j$ 的方差为 $\eta(1-\eta)/n$。将这一参数用于全图，需要额外假设风机制处处相同，且已正确处理撞墙后留在原位的合并概率。若只观察墙边位置，若干不同滑移方向可能产生相同后继状态，不能再把每条记录直接当作可观测的 X_j。

共享模块可以表达“几何碰撞规则相同，风模块变化”；平滑模型可以表达“小幅改变 η 只小幅改变转移”。前者减少重复估计的对象，后者约束插值误差，两者都不是从网络参数共享自动推出的事实。一般有限表格转移要估计约 $|\mathcal{S}||\mathcal{A}|(|\mathcal{S}|-1)$ 个自由概率，单个风参数只估计一个量，但这个维数比较不包含辨识它所需的访问成本。

反例更直接：在同一可见岔路，两个动作分别通向奖励 1 和 0 的区域；第二个任务将两个动作的物理效果互换，图像与奖励标记完全不变。旧策略仍选原来的动作，回报由 1 变为 0。旧后继特征预测它会访问奖励区域，因而同样失效；仅修改奖励权重不能把错误转移改对。这个单步例是从导航提取的教学简化，取消滑移与步成本。

模型误差还会传播到控制。若两个模型共享条件期望奖励 $R(s,a)$，满足 $|R| \le R_{\max}$，且转移满足 $\sup_{s,a}\|P_c - P_{c'}\|_1 \le \delta$，固定策略的 Bellman 关系给出

$$\|V_c^\pi - V_{c'}^\pi\|_\infty \le \gamma\|V_c^\pi - V_{c'}^\pi\|_\infty + \gamma\delta\,\frac{R_{\max}}{1-\gamma}.$$

移项得到上界 $\gamma\delta R_{\max}/(1-\gamma)^2$。若只是“进入终点得 1”的规则相同，改变到达概率仍可能改变 $R_c(s,a)$；两者仍满足同一 $R_{\max}$ 上界时，还要在价值界中加入 $\|R_c - R_{c'}\|_\infty/(1-\gamma)$，不能直接套用共同均值奖励的特例。这说明长期后果可能放大小的单步差异；它要求全相关状态动作的一致误差，训练参数范围内的平均预测误差不能代替该条件，更不能替范围外参数担保。

6.3.4 观测与动作接口变化下的可复用知识

把地图颜色换掉，并不一定改变小车的物理位置；交换左右动作标签，则会改变同一输出命令的控制效果。对一段“右、右、上”的命令序列，单

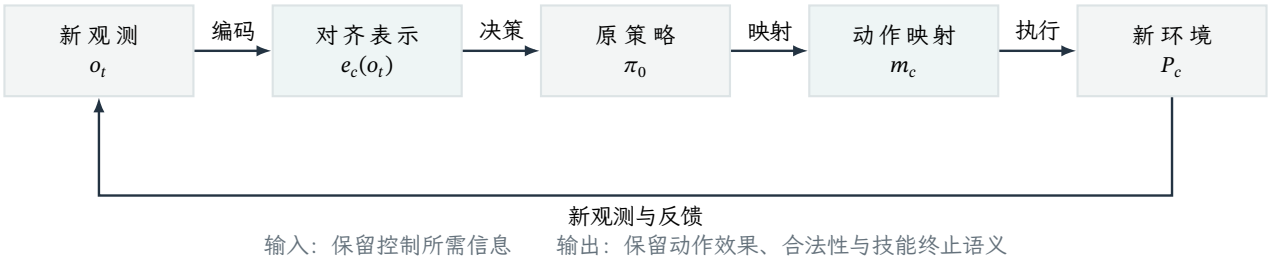


图 6.4 观测和动作接口的迁移。输入编码需要保留控制信息，输出映射需要保留物理效果与合法性；任何一侧缺少对应关系，原策略都不能原样解释新接口。图为上述充分条件的原创结构示意。

纯换色后物理轨迹可以完全不变，交换命令后却可能向相反方向移动，甚至使命令不再合法。因此输入与输出应分别对齐。

设新观测编码为 $e_c(o)$，它映射到原策略使用的决策表示；动作映射 $m_c(a)$ 把原语义动作变为新环境命令。若潜在状态之间有对应 f_c，精确复用的一个充分条件是奖励保持且

$$P_c\big(f_c^{-1}(B) \mid s, m_c(a)\big) = P_0(B \mid f_c(s), a)$$

对所有相关状态、合法动作与后继集合 B 成立，同时 e_c 保留决策所需信息、m_c 保持合法性。这是控制效果的对应，不只是颜色或向量之间的相似。图 6.4 分别标出编码、决策、映射与执行。

对于技能，还要把启动状态映射到原启动集，把“到达出口”映射到相同的终止事件。只映射原始动作，而忽略技能结束条件，可能导致高层策略等待一个永远不会到来的反馈。

有限日志未必能唯一确定这些映射。若日志只记录“上”和“下”，左右动作交换前后与全部记录相容；图像重建也无法辨认未试过命令的含义。需要增加有区分力的动作记录，或者提供可信的接口说明。控制充分表示与数据可识别性的区别见第 4 章：同尺寸接口、感知相似度和重建成功都不够。

6.3.5 组合与支持外任务所需的额外假设

训练时见过“远终点、无风”和“近终点、有风”，并不意味着已经见过“远终点、有风”。若目标模块只改变奖励、风模块只改变转移，且二者接口独立，模型可以组合这两种知识；若有一个仅在远终点且有风时出现的障碍，原来的两项任务却完全不能揭示它。

形式上，令 $c = (g, \eta)$。边缘支持分别为 $\mathrm{supp}(p_g)$ 和 $\mathrm{supp}(p_\eta)$，联合支持则为 $\mathrm{supp}(p_{g,\eta})$。一般只有

$$\mathrm{supp}(p_{g,\eta}) \subseteq \mathrm{supp}(p_g) \times \mathrm{supp}(p_\eta),$$

不保证相等。**组合泛化**（compositional generalization）要求把已学因素按未见组合使用；成立依据可能是 $P_c = P_\eta$、$R_c = R_g$ 等因子分解，以及组合后仍成立的观测、动作与终止接口。这些条件必须单独验证。

可以构造两个生成器：它们在已见组合上给出完全相同的地图，只在“远且有风”时分别保持通路或封闭通路。任何只用现有训练组合的算法面对两者都接收相同数据，因而不能仅凭这些数据确定新组合是否可通行。增加同一组合的轨迹数量无法消除这个歧义。

从未见过的新动作效果则更强：即使所有旧因素能正确组合，也没有定义它怎样作用于环境。支持外外推需要可识别的机制、适用范围明确的平滑性或结构不变性。测试应分别留出组合与因素范围；“训练了很多任务”不能代替对这种关系的证据。

6.4 可复用决策知识的训练

训练任务和经验已经给定后，需要选择它们进入哪个预测或决策目标。任务随机化、条件化、蒸馏和目标重标记是训练手段；表示、模型、价值和策略才是被训练的对象。同一种手段可以服务多个对象，其有效性仍受前两节的共享条件与任务支持约束。

6.4.1 训练任务与经验的构造

参数随机化可以每次抽取目标坐标和风强度；程序化关卡还可以抽取地图，但必须检查连通性、合法动作和终止规则。无论任务生成多复杂，得到经验仍有两个步骤：按 $q(c)$ 抽取任务，再由该任务中的收集策略 μ_c 产生轨迹。折扣情形下，若用归一化占用度量抽样，经验权重为 $q(c)d_c^{\mu_c}(s,a)$。某任务被频繁抽到，不代表其关键窄路也被充分访问。

任务采样权重还会改变优化目标。若希望优化 $p_{\text{训练}}$ 下的平均量，却用 q 抽任务，需要 $p_{\text{训练}}$ 相对于 q 绝对连续，并使用相应概率或密度比 $p_{\text{训练}}(c)/q(c)$。离散情形下，这要求每个 $p_{\text{训练}}(c) > 0$ 的任务都有 $q(c) > 0$；从未采样的任务不能靠重加权补回。权重过大会增加方差。课程学习选择当前较难的任务时，也应报告实际任务权重，而不是把采样改变隐藏在“多训练一些”之中。

有些失败轨迹无需重新交互，就能回答另一个目标的问题。**事后经验回放**（hindsight experience replay, HER）把轨迹实际达到的位置当作替代目标，重算该目标下的反馈，再交给离策略学习器。它重新解释了已经发生的转移，没有制造另一条物理轨迹[2]。

例如，教学轨迹从 $(1,1)$ 出发，依次到达 $(2,1)$、$(3,1)$ 和 $(4,1)$，没有到达原目标 $(4,3)$。用新目标 $g' = (3,1)$，设到达目标得 1、之前每步得 -0.04，则前两条转移的奖励由 $(-0.04,-0.04)$ 改为 $(-0.04,1)$。若新任务到达目标

[2] M. Andrychowicz, F. Wolski, A. Ray, J. Schneider, R. Fong, P. Welinder, B. McGrew, J. Tobin, P. Abbeel, W. Zaremba, *Hindsight Experience Replay* In Advances in Neural Information Processing Systems, 2017

立即结束，第二条转移的终止标记必须同时改为 1，后续从 $(3,1)$ 继续移动的记录不能接在这条新回合后作为有效经验。图 6.5 区分真实采集与离线重标记。

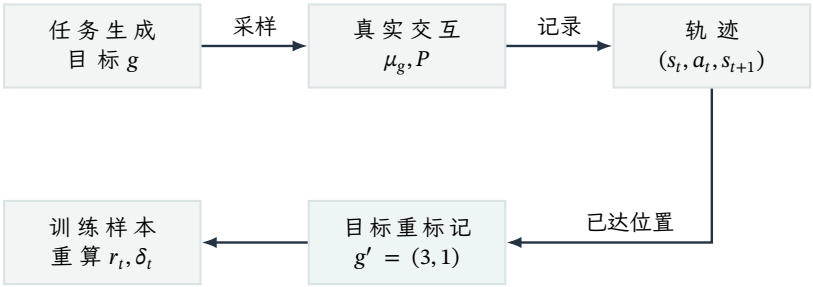


图 6.5 任务生成与目标重标记的两条数据路径。上行产生真实轨迹，下行重算已有轨迹的目标、奖励和终止标记；重标记箭头不回连环境，因而不增加真实状态动作覆盖。原理据 HER，具体导航路径为本章教学构造。

重标记的语义有效性至少要求：目标不改变非终止物理转移，奖励及目标相关终止信号可按记录重算，动作在新解释中仍合法。若开门目标同时改变门是否锁住，就不能把旧转移当作新目标样本。即使语义有效，随机环境中的选择偏差仍是另一个问题。

设教学单步任务的同一个动作以各 $1/2$ 概率落在左、右地标，且目标不影响转移。真实左目标下成功概率为 $1/2$；如果只把“实际落在左边”的记录重标成左目标，再用这些记录估计该动作的左目标成功率，就得到 1。每条保留记录都可能真实发生，但条件选择删除了失败分支。确定性动力学可避免这种特定的随机结果选择问题，随机环境则需检查重标记分布或采用适当校正；“目标不改变转移”本身不能证明估计无偏。

重标记 m 个目标会把每条原始记录扩成至多 m 条训练记录，奖励重算约需 $O(m)$ 次调用。增加的是训练计算与目标覆盖，不是 m 倍独立环境证据。

6.4.2 可复用状态表示的训练

不同终点任务都需要辨认障碍位置，但不应把目标位置压成同一个常量。所谓任务不变表示，应保留共同的控制要素，同时为会改变决策的任务变量留下入口。若表示把“同一地图”误解为“同一最优动作”，共享就会制造冲突。

共享编码器写作 $\boldsymbol{z} = e_\theta(o)$，策略或价值另接任务描述 c；任务条件表示写作 $\boldsymbol{z} = e_\theta(o, c)$，在编码时就解释目标；模块化表示可以写作 $\boldsymbol{z} =$

设计	共享部件	任务特定部件	训练信号	任务权重	适用条件
共享编码器	感知与几何表示	条件头或独立头	TD 误差、策略梯度、预测	显式 $q(c)$	编码未丢目标相关信息
条件表示	编码规则和参数	描述 c 或历史变量	条件价值、控制与预测	相同总量下检查各任务	描述语义及条件支持兼容
模块化表示	共同子模块及组合器	风、传感器等模块	模块预测与端到端控制	可按模块或任务平衡	分解与组合接口成立

表 6.4 三种表示设计。训练信号可以组合，但“参数共享”只描述实现，不能替代控制充分性证明。各列为本章机制归纳。

$(e_\theta(o), e_{\omega_c}(o,c))$，将共同几何与特定传感或动力学信息分开。三种设计都可输入 $Q(\boldsymbol{z},a,c)$、$\pi(a \mid \boldsymbol{z},c)$ 或潜在转移模型，表 6.4 固定这些用途比较。

例如，以共享编码器输入一个评论家，一条经验给出的目标为 $y_t = r_t + \gamma(1-\delta_t)\max_{a'} \overline{Q}(e_{\overline{\theta}}(o_{t+1}), a', c)$，其中 δ_t 是任务真正终止的标记。最小化 $\frac{1}{2}(Q(e_\theta(o_t), a_t, c) - y_t)^2$ 时，梯度通过评论家进入编码器；目标网络在此次梯度中固定。重建损失可以辅助感知，但只有控制目标或充分性条件才能说明为什么该表示保留了动作选择所需信息。

在一个教学单步岔路中，目标左与目标右需要相反动作。若两项任务被编码为完全相同的输入，任何确定策略都只能满足其中一项；加上一个目标位即可消除这个表示冲突。另一方面，若左任务占采样的 90%，总体正确率 90% 的常向左策略可能完全放弃右任务。这是任务权重造成的平均优势，不是两项任务都获得迁移。

训练计算随编码器前后向成本和样本数增长；多头设计还随任务头数量增加存储，模块化则增加组合与路由成本。诊断时应报告分任务回报、目标位消融与匹配容量的独立模型，区分信息被丢弃、容量不足和优化冲突。总体损失下降不能回答这些不同问题。

6.4.3 可复用环境模型的训练

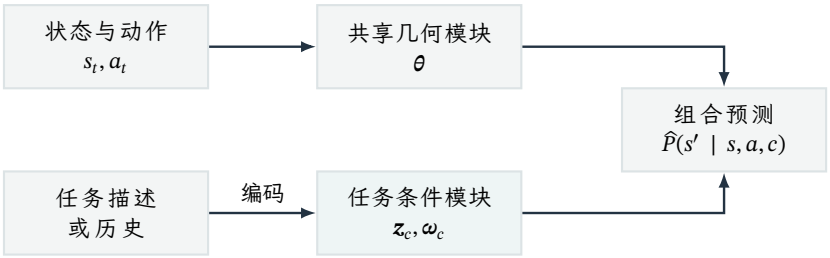
共同地图中的不同风向提示一种分工：碰撞几何可以共享，偏移方向由任务控制。令 $\widehat{P}_{\theta,\omega_c}(s' \mid s,a,\boldsymbol{z}_c)$ 预测下一状态，其中 θ 为共享参数，ω_c 为可选的任务特定参数，$\boldsymbol{z}_c$ 为描述或历史推断出的任务变量。奖励头与观测头若也训练，应分别写作 $\widehat{R}$ 和 $\widehat{O}$；没有训练这些头就不能把模型称为包含全部反馈的模拟器。

以完全可观测的转移预测为例，取每条长度 H 的训练轨迹平均负对数似然：

$$\mathcal{L}_{\text{模型}} = \mathbb{E}_{c\sim q}\mathbb{E}_{\tau\sim p_c^{\mu_c}}\left[-\frac{1}{H}\sum_{t=0}^{H-1}\log \widehat{P}_{\theta,\omega_c}(s_{t+1} \mid s_t, a_t, \boldsymbol{z}_c)\right]. \tag{6.2}$$

该目标来自最大化所采轨迹的条件转移似然；条件在已记录的 s_t, a_t 上，因而不把收集策略当成待拟合的动力学。不同长度回合按回合平均还是按步平均会赋予不同权重，必须选定一种。本式固定 H，并以任务平均而非把全部记录直接混在一起定义目标。

图 6.6 展示共同几何与任务条件模块如何组合。完全共享模型相当于忽略 $\boldsymbol{\omega}_c, \boldsymbol{z}_c$；完全独立模型则为每项任务各拟合全部参数。模块化减少的是共同几何的重复估计，仍需估计新风向，不能以共享参数比例推算目标样本效率。



完全共享：忽略任务条件
完全独立：每项任务复制全部模块

图 6.6 任务条件环境模型。状态动作进入共享模块，描述或历史进入任务模块，两者共同决定转移预测；奖励、观测头仅在确实训练时增加。图为本章模型参数化的原创示意，不表示所有环境都满足这种分解。

一个可复核的教学例是前述一维风参数。在 8 次可辨认滑移的独立试验中观察到 2 次偏离，负对数似然为 $-2\log\eta - 6\log(1-\eta)$。令导数 $-2/\eta + 6/(1-\eta) = 0$，得到 $\hat{\eta} = 1/4$。随后把 $\hat{\eta}$ 送入共同碰撞模型，计算所有位置的转移；这一步依赖“同一个风参数适用于全图”的结构假设。

训练时知道 c，部署时却只有历史，是一个额外推断问题。应训练从可见历史到 $\boldsymbol{z}_c$ 的编码器，并在测试中只给这些历史；不能把真实风标签作为隐蔽输入。固定日志上的训练成本约为数据量乘单样本模型前后向成本，模型内规划还要乘候选动作序列数及前瞻深度。未覆盖风向、传感器变化和反复滚动的误差累积，都可能使训练似然较好的模型产生错误策略。

6.4.4 可复用价值与策略的训练

同一岔路在不同目标下需要不同动作，价值函数必须看见目标。目标条件 MDP 把目标 g 纳入任务描述，**通用价值函数逼近器**（universal value function approximator, UVFA）用一个 $Q_\theta(s, a, g)$ 同时概括状态与目标上的价值。它可以通过多目标 TD 目标训练：从任务 g 的行为策略采样，按该目标重算奖励和终止，拟合 $r_t + \gamma(1-\delta_t)\max_{a'} \overline{Q}(s_{t+1}, a', g)$。动作选择也必须查询相同的 g，不能训练时条件化、执行时却丢掉它[3]。

[3] T. Schaul, D. Horgan, K. Gregor, D. Silver, *Universal Value Function Approximators* In Proceedings of the 32nd International Conference on Machine Learning, 2015, pp. 1312–1320

一个共享评论家可在网络中联合表示所有目标；多头输出保留共同特征、为每个已见任务独立输出价值；模块化策略则让不同模块处理几何、目标或控制模式。多头编号本身不解释新目标，UVFA 的连续输入也不自动带来外推能力。单条 TD 更新至少要计算当前价值与目标动作值，有限动作枚举成本随 $|\mathcal{A}|$ 增加，连续动作则需要行动者或其他最大化近似。

后继特征提供了更明确的价值复用条件。其前身**后继表示**（successor representation, SR）在固定策略下记录未来访问各状态的折扣次数。有限状态时可定义

$$M^{\pi}(s,u)=\mathbb{E}_{\pi}\left[\sum_{t\geq 0}\gamma^{t}\mathbb{I}\{s_t=u\}\mid s_0=s\right].$$

若 $\boldsymbol{P}^{\pi}$ 为策略诱导的状态转移矩阵，则拆出 $t=0$ 项得 $\boldsymbol{M}^{\pi}=\boldsymbol{I}+\gamma\boldsymbol{P}^{\pi}\boldsymbol{M}^{\pi}$，从而 $\boldsymbol{M}^{\pi}=(\boldsymbol{I}-\gamma\boldsymbol{P}^{\pi})^{-1}$。逆矩阵存在是因为随机矩阵的谱半径不超过 1 且 $\gamma<1$。该表示一般存储 $|\mathcal{S}|^2$ 个数；将状态指示量换成低维事件特征，就得到 SF[4]。

[4] P. Dayan, *Improving Generalization for Temporal Difference Learning: The Successor Representation* In Neural Computation, 1993, vol. 5, no. 4, pp. 613–624

定义 6.2　固定策略的后继特征　在共同动力学 P、共同折扣 $0\leq\gamma<1$ 与一致状态动作语义下，设 $\sup_{s,a,s'}\|\boldsymbol{\phi}(s,a,s')\|_2\leq C_{\phi}<\infty$。固定平稳策略 π 的后继特征为

$$\boldsymbol{\psi}^{\pi}(s,a)=\mathbb{E}_{\pi}\left[\sum_{t=0}^{\infty}\gamma^{t}\boldsymbol{\phi}(s_t,a_t,s_{t+1})\,\middle|\,s_0=s,a_0=a\right].\tag{6.3}$$

首动作按条件强制执行，之后服从 π。

现在完整连接这个对象与价值。对随机奖励，另假设各状态动作下的绝对一阶矩有共同有限上界；有界奖励样本是一个充分条件，从而折扣奖励和可积。由特征有界性，$\sum_{t\geq 0}\gamma^{t}\|\boldsymbol{\phi}_t\|_2\leq C_{\phi}/(1-\gamma)$；对固定有限 $\boldsymbol{w}_c$，条件期望奖励的绝对折扣和也有上界 $C_{\phi}\|\boldsymbol{w}_c\|_2/(1-\gamma)$。因此可以用支配收敛把部分和的极限移入期望，并用条件期望先把 r_t 替换成转移条件期望奖励。依次得到

$$\begin{aligned}Q_c^{\pi}(s,a)&=\lim_{N\to\infty}\mathbb{E}_{\pi}\left[\sum_{t=0}^{N}\gamma^{t}R_c(s_t,a_t,s_{t+1})\mid s_0=s,a_0=a\right]\\&=\lim_{N\to\infty}\left\langle\mathbb{E}_{\pi}\left[\sum_{t=0}^{N}\gamma^{t}\boldsymbol{\phi}_t\mid s_0=s,a_0=a\right],\boldsymbol{w}_c\right\rangle\\&=\langle\boldsymbol{\psi}^{\pi}(s,a),\boldsymbol{w}_c\rangle.\end{aligned}\tag{6.4}$$

第二步使用式 (6.1) 与有限和、内积的线性性，第三步使用前述可积性。SF 不含奖励权重，却仍依赖 P 和 π；在新任务换掉转移后，原式右侧不再使用正确的轨迹分布。

拆出第一步特征，得到向量 Bellman 方程

$$\boldsymbol{\psi}^{\pi}(s,a)=\mathbb{E}_{s'\sim P}\left[\boldsymbol{\phi}(s,a,s')+\gamma\mathbb{E}_{a'\sim\pi(\cdot|s')}\boldsymbol{\psi}^{\pi}(s',a')\right]. \tag{6.5}$$

因此可沿用价值评价的采样方法。表格情形从覆盖相关状态动作的行为策略 μ 取得转移，计算 $\boldsymbol{y}_t=\boldsymbol{\phi}_t+\gamma\sum_{a'}\pi(a'\mid s_{t+1})\widehat{\boldsymbol{\psi}}(s_{t+1},a')$，再令 $\widehat{\boldsymbol{\psi}}(s_t,a_t)$ 向 $\boldsymbol{y}_t$ 移动步长 α。终止时继续项为 0。若仅采样一个 $a'\sim\pi$，则以该样本替代动作期望。这里评价的是固定 π，不能无说明地把下一动作改成最大值。表格每次更新的向量运算为 $O(d|\mathcal{A}|)$，采样下一动作时为 $O(d)$；网络实现还包含前后向成本。

新权重未知时，可从目标奖励样本最小化 $\sum_j(r_j-\boldsymbol{\phi}_j^{\top}\boldsymbol{w}_c)^2$；要唯一辨认权重，数据特征矩阵还需足够秩。若权重由目标描述直接给出，则不需要目标反馈拟合这一步，但仍需要在共同动力学下学好的 SF。

已有多条策略时，可以在每个状态重新选动作，而不必整回合只运行某一条。**广义策略改进**（generalized policy improvement, GPI）先用同一目标奖励评价每条策略，再对它们的动作价值上包络取贪心。下面的保证比较已有策略，而不是未知的新任务最优策略[5]。

定理 6.3　有一致估计误差的广义策略改进　在同一个有限状态动作、有界奖励的折扣 MDP 中，给定有限平稳策略集 $\{\pi_1,\dots,\pi_m\}$。若所有状态动作均满足 $|\widehat{Q}^{\pi_i}(s,a)-Q^{\pi_i}(s,a)|\le\varepsilon$，定义

$$\pi(s)\in\arg\max_{a\in\mathcal{A}(s)}\max_{i}\widehat{Q}^{\pi_i}(s,a),$$

并固定平局规则，则

$$Q^{\pi}(s,a)\ge\max_{i}Q^{\pi_i}(s,a)-\frac{2\varepsilon}{1-\gamma}. \tag{6.6}$$

证明思路的关键是把一次近似贪心损失变成可以递推的 Bellman 不等式。令 $f(s,a)=\max_i Q^{\pi_i}(s,a)$、$\widehat{f}(s,a)=\max_i\widehat{Q}^{\pi_i}(s,a)$；一致误差保证 $|f-\widehat{f}|\le\varepsilon$。由 π 的贪心定义，

$$f(s,\pi(s))\ge\widehat{f}(s,\pi(s))-\varepsilon=\max_a\widehat{f}(s,a)-\varepsilon\ge\max_a f(s,a)-2\varepsilon.$$

[5] A. Barreto, W. Dabney, R. Munos, J. J. Hunt, T. Schaul, H. van Hasselt, D. Silver, *Successor Features for Transfer in Reinforcement Learning* In Advances in Neural Information Processing Systems, 2017

两次误差分别来自所选动作和最佳动作。用 T^{π} 表示动作价值的 Bellman 评价算子，便有

$$\begin{aligned} T^{\pi} f &\geq R + \gamma P \max_{a} f - 2\gamma\varepsilon \\ &\geq \max_{i} \{R + \gamma P \mathbb{E}_{a' \sim \pi_i} Q^{\pi_i}\} - 2\gamma\varepsilon \\ &= f - 2\gamma\varepsilon \geq f - 2\varepsilon. \end{aligned}$$

其中 P 表示对后继状态取期望；第二行用“每个后继状态上的最大值至少覆盖任一 π_i 的动作平均”，再对策略取最大。Bellman 单调性以及 $T^{\pi}(f - b) = T^{\pi} f - \gamma b$ 给出 $(T^{\pi})^k f \geq f - 2\varepsilon \sum_{j=0}^{k-1} \gamma^j$。压缩性保证左侧收敛到 Q^{π}，几何级数收敛到 $1/(1-\gamma)$，于是得到式 (6.6)。这一关系也说明深度网络上小的平均 TD 损失不等于定理要求的全状态动作一致误差。

示例 6.4　两条绕障策略的新奖励评价　以下简化保留导航地图与固定吸收出口 $(4, 3)$，取消滑移与步成本，沿途地标允许重复计分。取特征为进入 $(1, 3)$、进入 $(4, 1)$、首次进入出口的三个指示量，吸收后特征为 0，$\gamma = 0.9$。两条确定策略从起点分别走“上、上、右、右、右”和“右、右、右、上、上”；离开这两条路线的状态可用任一固定合法规则补全策略。

上路在 $t = 1$ 经过第一个地标，$t = 4$ 进入出口；下路在 $t = 2$ 经过第二个地标，$t = 4$ 进入出口。因此从起点执行各自首动作并继续原策略时，

$$\boldsymbol{\psi}^{\pi_1} = (0.9, 0, 0.6561)^{\top}, \qquad \boldsymbol{\psi}^{\pi_2} = (0, 0.81, 0.6561)^{\top}.$$

新权重 $\boldsymbol{w} = (1, 2, 1)^{\top}$ 给出两条完整路线的回报 1.5561 与 2.2761。固定调用下路优于固定调用上路；GPI 则需为每个候选首动作查询每条补全策略的 SF，再逐状态选择，不能仅凭这两个整路线数字实现。

当 SF 精确时，GPI 在各状态不会劣于库内任一策略；当所有动作价值一致误差至多为教学假设 $\varepsilon = 0.01$ 时，本定理给出的逐动作损失容限为 0.2。从状态开始执行 GPI 也满足同样的保守容限：近似贪心至多损失 2ε，后续至多损失 $2\gamma\varepsilon/(1-\gamma)$。这些保证没有比较库外最优策略；地标重复奖励甚至可能使有益循环优于直接离场。

策略库有 m 条策略、每个 SF 为 d 维时，直接 GPI 查询约需 $m|\mathcal{A}|$ 个 SF 输出和 $O(m|\mathcal{A}|d)$ 次乘加。相比每个新奖励都从头学习，它复用了后果计算；相比单次策略前向，它增加了查询成本。新奖励残差、新动力学误差和策略库缺失各自需要额外分析，不能全塞进未经测量的 ε。

对象	保存什么	目标任务还需做什么	接口与边界
价值与 SF	指定行为的长期后果	重加权、策略改进或价值重估	奖励类、共同转移、策略语义
蒸馏策略	教师动作分布	条件调用或额外适应	输入与动作对齐；日志外误差
可迁移初始化	适合更新的参数起点	用获准数据做有限更新	步长、梯度质量、更新后评价
技能库	启动集 I_o、输入、π_o、β_o	选择、组合或调整内部控制	动作效果、持续时间与终止含义兼容

表 6.5 行为知识的四种保存方式。技能“能够运行”只验证部分接口，不保证适合新目标；表中没有把它们视为互斥算法类别。

另一种保存行为的方法是**策略蒸馏**（policy distillation）：在教师策略访问的状态上，让学生拟合教师动作分布。以共同动作接口为例，可最小化

$$\mathcal{L}_{\text{蒸馏}} = \mathbb{E}_{c\sim q,\, s\sim \nu_c}\, \mathrm{KL}\Big(\pi_c^{\text{教师}}(\cdot \mid s) \,\|\, \pi_\theta(\cdot \mid s, c)\Big).$$

ν_c 说明教师或其他行为收集的状态分布，梯度只更新学生。一个教学二动作教师给出 $(0.8, 0.2)$，学生给出 $(0.5, 0.5)$，则交叉熵对学生两个 logit 的梯度为 $(-0.3, 0.3)$，一次更新提高第一动作概率。压缩多个教师省去部署时多个网络的独立调用，但没有保存教师如何从失败中学习的过程，日志外状态仍可能失配。原始策略蒸馏工作以多任务策略压缩为主要用途[6]。

若部署允许少量梯度更新，训练目标可以直接考虑更新后的表现。**模型无关元学习**（model-agnostic meta-learning, MAML）学习一个适合后续更新的初始化。这里“模型无关”指适用于不同可微参数模型，不是强化学习中“无模型”的分类。令 $L_c(\theta) = -J_c(\pi_\theta)$ 为负回报，任务内更新算子为 U_c，元目标写为

$$\min_\theta\ \mathbb{E}_{c\sim p_{\text{训练}}} \mathbb{E}_{\mathcal{D}_c^{\text{内}}\sim p_c^{\pi_\theta}} L_c\Big(U_c(\theta, \mathcal{D}_c^{\text{内}})\Big). \tag{6.7}$$

外层抽任务，内层由当前策略采样并更新；更新后的策略还要在同一任务重新采集 $\mathcal{D}_c^{\text{外}}$，估计更新后回报。外层不是让初始化立刻解决所有任务，而是让约定预算内的更新有用[7]。

对固定内层数据和可微更新 $\theta' = \theta - \alpha \nabla \hat{L}_c^{\text{内}}$，链式法则给出条件导数

$$\nabla_\theta L_c(\theta') = \Big(\boldsymbol{I} - \alpha \nabla_\theta^2 \hat{L}_c^{\text{内}}\Big)^{\top} \nabla_{\theta'} L_c(\theta').$$

在强化学习中，内层数据分布本身依赖 θ；若要求式 (6.7) 的完整梯度，还存在 $L_c(\theta')\nabla_\theta \log p_c^{\pi_\theta}(\mathcal{D}_c^{\text{内}})$ 这一采样分布项。把已采轨迹当作固定张量、对普通策略梯度代理反传，并不自动得到无偏的完整高阶梯度。必须说明使用的估计器及省略项；具体目标任务更新见第 6.5.4 节。

表 6.5 比较四种保存方式。技能还需保存启动集 I_o、内部策略 π_o 及终止概率 β_o；其发现机制见第 3 章。这里的关键区别是保存已有动作规律、可重加权的后果，还是未来更新的起点。

[6] A. A. Rusu, S. Gómez Colmenarejo, Ç. Gülçehre, G. Desjardins, J. Kirkpatrick, R. Pascanu, V. Mnih, K. Kavukcuoglu, R. Hadsell, *Policy Distillation* In International Conference on Learning Representations, 2016

[7] C. Finn, P. Abbeel, S. Levine, *Model-Agnostic Meta-Learning for Fast Adaptation of Deep Networks* In Proceedings of the 34th International Conference on Machine Learning, 2017, pp. 1126–1135

6.5 目标任务策略的形成

共享模型或策略训练完毕，并不意味着目标任务策略已经确定。给定新目标可以直接查询条件策略；隐藏风向则需要从反馈中推断。新的信息可以存入记忆、任务后验或网络参数，是否允许继续收集信息又是另一项权限。本节先说明信息怎样形成，再分别讨论这些可以组合的机制。

6.5.1 从显式描述与交互历史形成任务信息

考虑导航任务的一个独立教学变体：终点已知，风向 $c \in \{\text{左风}, \text{右风}\}$ 在整个试验期间固定，先验各为 $1/2$。终点描述没有包含风向信息。在一个获准的测试位置，某个试探动作产生可见“右偏”的概率在两项任务中分别为 0.2 和 0.8。观察一次右偏会改变对风向的判断；反复撞上同一堵墙，如果两种风都只留下“位置未变”，就可能完全没有区分力。数字仅用于说明似然更新，未作为基准网格的新转移解。

设当前物理状态可见，历史为 $h_t = (s_0, a_0, r_0, \delta_0, \dots, s_t)$，其中 δ_t 记录动作 a_t 之后的终止事件。有限任务集合上的**任务信念**（task belief）$b_t(c) = \mathbb{P}(c \mid h_t)$ 是给定已见证据后对任务的概率分布。显式描述可以约束先验或直接确定某些任务分量；它与历史证据应进入同一条件化过程，而不是相互替代。若初始状态分布也随任务变化，看到 s_0 时便已有证据：描述条件下的先验为 $p_0(c)$ 时，$b_0(c) \propto p_0(c)\rho_{0,c}(s_0)$，不能无条件沿用 p_0。

令 $\ell_c(s_{t+1}, r_t, \delta_t \mid s_t, a_t)$ 为任务 c 中可用模型给出的联合似然。任务固定、奖励及终止模型正确，且动作仅由已记录历史和独立随机数选择时，贝叶斯公式给出

$$b_{t+1}(c) = \frac{b_t(c)\,\ell_c(s_{t+1}, r_t, \delta_t \mid s_t, a_t)}{\sum_{\tilde{c} \in \mathcal{C}} b_t(\tilde{c})\,\ell_{\tilde{c}}(s_{t+1}, r_t, \delta_t \mid s_t, a_t)}. \tag{6.8}$$

分母为所见反馈的预测概率，需大于 0。推导中，联合概率包含 $b_t(c)\pi(a_t \mid h_t)\ell_c(\cdot)$；动作概率在各候选任务间相同，故在归一化时消去。若收集者另知隐藏任务并据此选动作，却未记录这项信息，就不能不加分析地消去它。

前述右偏观测给出 $b_{t+1}(\text{右风}) = 0.8/(0.8 + 0.2) = 0.8$。若独立重置到测试位置后又观察一次右偏，则后验为 $0.8^2/(0.8^2 + 0.2^2) = 16/17$。任务后验改变的是对固定对象的认识，不是风向本身。若物理状态也隐藏，应维护 $b_t(s, c) = \mathbb{P}(s_t = s, c \mid h_t)$，先对旧状态求和预测，再乘观测与奖励似然；不能用一个任务向量代替状态滤波而省去所需条件。

精确枚举有限任务的单步更新需要 $|\mathcal{C}|$ 次似然计算；状态同时隐藏时还包含状态转移求和。大任务空间通常改用历史编码器近似推断。图 6.7 将推断和控制组成闭环，虚线单独标出训练时的监督或变分目标，避免把网络输出误画成真实任务标签。

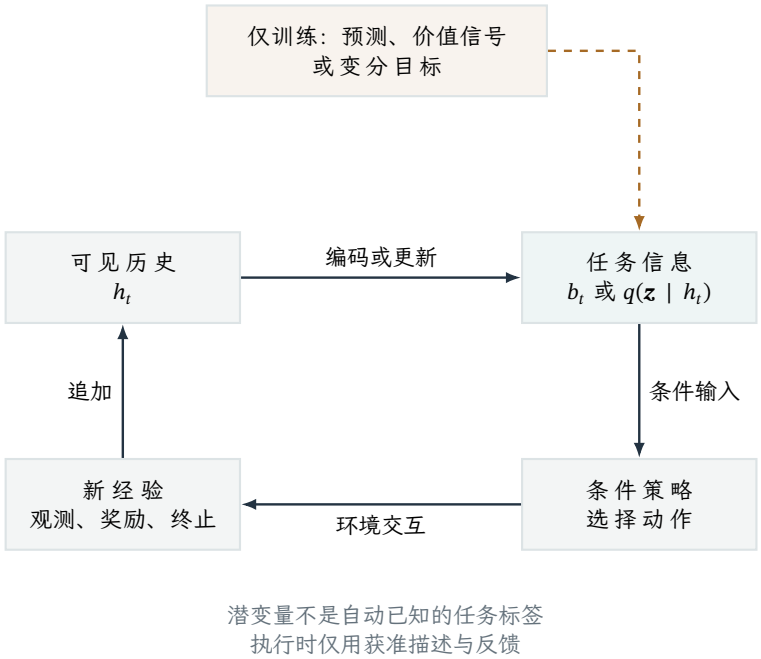


图 6.7 任务信息与行为的闭环。实线为执行时可见的信息流，虚线为训练时用于塑造推断器的目标；“任务信息”可以是精确后验、近似分布或普通记忆，三者不能仅因向量维数相同就互换。图为本章机制的原创归纳。

PEARL 用转移上下文 $\mathcal{C}_t$ 形成近似分布 $q_{\varphi}(\boldsymbol{z} \mid \mathcal{C}_t)$，再从中抽样 $\boldsymbol{z}$，交给条件策略与评论家。其原始设计把各条上下文对应的高斯因子组合起来，适合任务固定、转移可按集合处理的情形；离策略回放用于训练评论家与策略，上下文编码器由价值学习信号及相对先验的 KL 正则约束。训练抽任务、抽该任务上下文、抽回放转移，更新相应损失；部署则收集允许的少量转移、更新潜变量分布并再抽样行为。这里保存的是近似任务信息，不是已知真实风标签[8]。

VariBAD 也近似任务后验，但通过循环编码历史与变分目标学习潜变量：以潜变量重建同一任务的奖励和转移，并用 KL 项约束后验与先验或先前后验。条件策略读取后验的参数，而不只读取一个任务点估计，训练时以跨回合回报学习兼顾信息获取与利用。其执行阶段不需要调用训练用解码器做模型内规划。因此，“有预测解码器”不等于“部署时基于模型规划”[9]。

两种设计的取舍可以在同一个右偏例子中检查。精确二任务模型给出 0.8 这一可核后验；近似编码器则需检验同类历史的预测与校准，不能要求某个潜变量坐标也恰好等于 0.8。PEARL 式抽样让一次行为在某个任务假设下连贯执行，VariBAD 式条件策略可利用分布的不确定性决定是否再探测；它们是否学到有效探索仍依赖训练任务与反馈。前者要计算上下文因子及条件策略，后者要逐步维护循环状态和后验参数；两者训练还包含评论家或解码器成本，不能只比较策略前向次数。

[8] K. Rakelly, A. Zhou, D. Quillen, C. Finn, S. Levine, *Efficient Off-Policy Meta-Reinforcement Learning via Probabilistic Context Variables* In Proceedings of the 36th International Conference on Machine Learning, 2019, pp. 5331–5340

[9] L. Zintgraf, K. Shiarlis, M. Igl, S. Schulze, Y. Gal, K. Hofmann, S. Whiteson, *VariBAD: A Very Good Method for Bayes-Adaptive Deep RL via Meta-Learning* In International Conference on Learning Representations, 2020

存在比近似误差更根本的限制。构造两个终点隐藏的教学任务：在最后一次岔路选择前，预算内所有获准动作的状态、奖励和终止分布完全相同；最终向左或向右分别只在其中一个任务成功，先验各为 $1/2$。任何历史编码器收到的数据分布相同，因此最终选择左的概率在两任务中相同。若该概率为 p，平均成功率为 $\frac{1}{2}p + \frac{1}{2}(1-p) = 1/2$。增加网络容量不能提高这项上限。只有允许额外访问会显示终点线索的状态，或提供带区分力的描述，主动辨识才可能改变信息条件。

6.5.2 无目标任务更新数据下的零样本策略

目标坐标已给出、输入语义与训练一致时，策略形成可以只是一次条件查询：$a_t \sim \pi_\theta(\cdot \mid s_t, g)$，或 $a_t \in \arg\max_a Q_\theta(s_t, a, g)$。若同时给出可解释的新奖励权重，还可计算

$$a_t \in \arg\max_a \max_i \langle \hat{\boldsymbol{\psi}}^{\pi_i}(s_t, a), \boldsymbol{w}_g \rangle.$$

后一种调用复用了 SF 策略库，不需要目标奖励样本；但共同动力学、终止与特征语义，以及第 6.3 定理的估计条件仍不能省略。

这里沿用第 6.1.3 节的零样本口径：禁止用目标反馈更新权重、任务记忆或选择检查点，无论更新发生在回合内还是跨回合。当前观测仍然可见，否则连位置控制都无法执行；预先约定的物理状态滤波与未知任务辨识应分开报告。若把偏移或奖励反馈送入历史编码器，据此推断风向并改变后续控制，就已发生任务适应，即使尚未结束第一个回合、也没有一次反向传播。

可以在同一训练模型上固定目标坐标格式、动作选择规则和推理次数，分别测试图 6.3 中的 $(1, 0.15)$、$(3, 0.3)$ 和 $(4, 0.45)$ 任务。它们依次代表支持内新任务、未见因素组合和范围外因素；训练参数与测试权限完全相同，变化的是所检验的任务关系。应分别报告三组零样本回报，而不是把它们合成一个“新任务平均分”。

若输入只有新编号 3，条件网络无法由数字推断它代表哪个终点。若新目标需要从未形成的控制方式，或目标设备交换了左右动作接口，旧策略库即使每条策略都能前向计算，也可能没有一个合法有效的候选。零样本能力来自已有知识与描述之间成立的关系，不来自关闭更新开关本身。

6.5.3 参数固定条件下基于上下文的策略适应

同一隐藏风向任务连续运行两个回合，第一回合先试探，第二回合依据偏移结果绕障，这已经是适应。变化可以只发生在记忆中。将“学习”等同于“修改网络权重”，会漏掉这种由历史改变决策规则的机制。

RL^2 以循环策略把快速学习过程放入内部状态[10]。执行时固定网络参数

[10] Y. Duan, J. Schulman, X. Chen, P. L. Bartlett, I. Sutskever, P. Abbeel, *RL^2: Fast Reinforcement Learning via Slow Reinforcement Learning* In arXiv preprint arXiv:1611.02779, 2016

θ，令

$$\begin{aligned} \boldsymbol{m}_t &= f_\theta(\boldsymbol{m}_{t-1}, o_t, a_{t-1}, r_{t-1}, \delta_{t-1}), \\ a_t &\sim \pi_\theta(\cdot \mid \boldsymbol{m}_t). \end{aligned} \tag{6.9}$$

首步的上一动作、奖励与终止标记使用约定的空值。终止标记说明上一动作结束了物理回合；环境此时重置位置，但同一任务的 $\boldsymbol{m}$ 继续保留。只有切换任务、开始新的独立适应试验时，才重置任务记忆。训练的慢过程在多项任务上优化跨多个回合的总回报，使早期收集信息可能由后续收益补偿。

图 6.8 把固定参数外框与可变记忆分开。在前述教学风任务中，可构造一个实现贝叶斯更新的记忆器：初始记忆存右风概率 1/2，第一个回合观察右偏后存 0.8，第二回合用新概率选择路线。这个例子证明固定参数可以实现适应，不声称训练出的 RL^2 必然等价于精确贝叶斯推断。

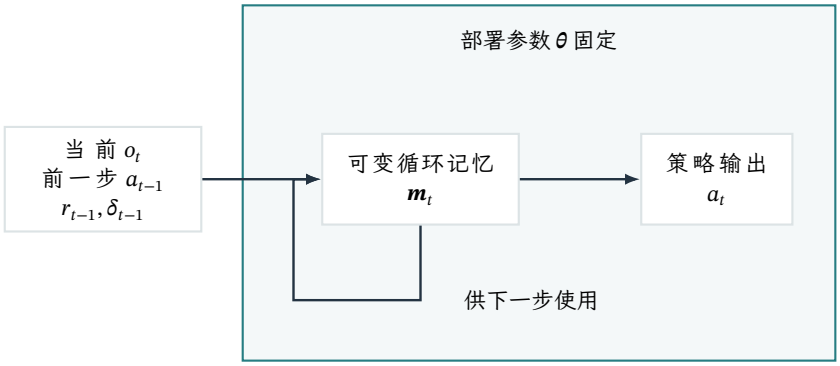


图 6.8　固定参数中的可变记忆。输入包含当前观测及上一动作对应的奖励和终止标记；同任务回合结束仅重置物理环境，任务改变才重置记忆。图据 RL^2 的交互协议重绘，贝叶斯数值例是本章构造，不是其训练结果。

循环记忆并不是唯一实现。Algorithm Distillation（AD，算法蒸馏）从源强化学习算法的多回合学习记录中抽取长序列，以自回归动作预测拟合 $-\sum_t \log \pi_\theta(a_t \mid h_t)$[11]。输入历史包括观测、动作与奖励，训练样本保留从探索到改进的顺序；部署时把自身新经历追加到历史，固定参数继续预测动作。它模仿的是学习过程中的行为变化，而前述策略蒸馏通常只压缩已训练教师的行为。

Decision Pretrained Transformer（DPT，决策预训练 Transformer）则以任务内上下文和查询状态预测教师最优动作。训练时从任务 c 抽取上下文 $\mathcal{D}_c$ 和查询 s，拟合 $-\log \pi_\theta(a_c^*(s) \mid s, \mathcal{D}_c)$；连续动作可使用相应密度损失。理想化地，若标签确为各任务最优动作、任务分布与上下文生成方式正确

[11] M. Laskin, L. Wang, J. Oh, E. Parisotto, S. Spencer, R. Steigerwald, D. Strouse, S. Hansen, A. Filos, E. Brooks, M. Gazeau, H. Sahni, S. Singh, V. Mnih, *In-context Reinforcement Learning with Algorithm Distillation* In International Conference on Learning Representations, 2023

方法	上下文内容	训练数据来源	目标反馈	策略提取
RL^2	观测、前动作、奖励、终止	多任务在线跨回合交互	同任务内逐步到达	循环记忆条件策略
AD	按顺序的多回合学习历史	源 RL 算法的学习轨迹	追加自身交互历史	自回归预测动作
DPT	任务内转移及查询状态	上下文与教师最优动作标签	给定上下文或新交互	监督条件动作分布
AdA	跨回合观测、动作与反馈	程序化任务、课程与在线 RL	试验内持续反馈	记忆条件的 RL 策略
S-ICQL	任务提示与交互上下文	世界模型提示和离线记录	在线或离线上下文	条件价值与优势加权策略
Vintix II	多领域转移上下文	含噪记录、示范者动作重标	在线或离线上下文	DPT 式条件化与流匹配动作头

表 6.6 固定参数上下文适应的不同训练信号。各方法的上下文、反馈量和策略提取成本必须单独核对；该表归纳原始方法，不表示使用相同数据得到的实验排名。

覆盖测试情形，监督条件分布会对仍与上下文相容的任务作后验混合。这解释了与后验采样的联系，不是任意有限网络都具备贝叶斯最优探索的保证[12]。

另一些方法直接以强化学习训练长期记忆。Adaptive Agent（AdA）在程序化任务空间与课程中训练带记忆的智能体，让跨回合反馈影响行为；其训练信号是交互回报，而非给定最优动作标签[13]。

Scalable In-Context Q-Learning（S-ICQL）把上下文条件化放进价值学习：利用世界模型生成任务提示，训练上下文条件的 Q/V，结合偏向高价值样本的 expectile 目标和优势加权策略提取；测试上下文可以来自规定的在线交互或离线记录。

Vintix II 沿用 DPT 式决策预训练思路，以多领域、含噪行为记录构造上下文，并用示范者动作重标记监督目标；连续动作生成采用流匹配目标。它同时研究在线与离线的上下文使用。此处的跨领域结果仍受所用低维观测、控制接口和训练任务支持约束，不能改写成任意视觉任务的通用保证。

表 6.6 按信息与策略形成方式对照这些方法。它们都能在固定参数下利用新上下文，但训练信号分别来自交互回报、学习历史中的动作、教师标签或条件价值估计。这些差别决定了模型能够从训练数据中学到什么，不能仅以是否使用 Transformer 判断适应机制。

表中的策略提取方式也影响上下文如何用于决策。AD 拟合学习历史中的动作，S-ICQL 则经由条件价值评价动作；其中 expectile 目标对正负残差赋予不同的二次损失权重，不是直接把最大样本当作真实最优值。二者都可在固定参数下适应，却不能仅按“是否预测下一个动作”视为同一种学习机制[14]。

[12] J. Lee, A. Xie, A. Pacchiano, Y. Chandak, C. Finn, O. Nachum, E. Brunskill, *Supervised Pretraining Can Learn In-Context Reinforcement Learning* In Advances in Neural Information Processing Systems, 2023, pp. 43057–43083

[13] J. Bauer, K. Baumli, F. Behbahani, A. Bhoopchand, N. Bradley-Schmieg, M. Chang, N. Clay, A. Collister, V. Dasagi, L. Gonzalez, K. Gregor, E. Hughes, S. Kashem, M. Loks-Thompson, H. Openshaw, J. Parker-Holder, S. Pathak, N. Perez-Nieves, N. Rakicevic, T. Rocktäschel, Y. Schroecker, S. Singh, J. Sygnowski, K. Tuyls, S. York, A. Zacherl, L. M. Zhang, *Human-Timescale Adaptation in an Open-Ended Task Space* In Proceedings of the 40th International Conference on Machine Learning, 2023, pp. 1887–1935

[14] J. Liu, F. Liu, Z. Sun, J. Hao, H. Li, B. Wang, D. Dong, C. Chen, Z. Wang, *Scalable In-Context Q-Learning* In International Conference on Learning Representations, 2026

这类方法的运行代价不止权重存储。循环策略每步更新固定维度记忆，长序列 Transformer 在朴素实现中对长度 L 的完整注意力计算为 $O(L^2)$；缓存可以减少重复计算，但仍要存储上下文及相关状态。条件价值可能需要额外候选动作评价；Vintix II 采用的流匹配动作头还需若干生成步骤[15]。比较时应报告实际上下文长度、缓存、推理次数与延迟，不把“零梯度步”写成“零适应成本”。

任务边界错误也会改变结果：把前一任务记忆带入下一任务会污染推断，过早清空记忆会丢掉跨回合证据；截断窗口可能删掉唯一的风向线索。学习轨迹若只有无效随机行为，AD 无法仅靠动作模仿获得未出现的改进规则；教师标签、世界模型和任务生成器也各有支持限制。训练中学到某种改进模式，并不意味着在任意新任务上都能保证探索和性能单调提升。

[15] A. Polubarov, N. Lyubaykin, A. Derevyagin, A. Grishin, I. Saprygin, A. Serkov, M. Averchenko, D. Tikhonov, M. Zhdanov, A. Nikulin, I. Zisman, A. Klepach, A. Zemtsov, V. Kurenkov, *Vintix II: Decision Pre-Trained Transformer is a Scalable In-Context Reinforcement Learner* In International Conference on Learning Representations, 2026

6.5.4 允许有限梯度更新下的参数适应

若协议允许用目标任务数据改动参数，复用初始化就成为一次有明确数据依赖的学习过程。设任务 c 在适应期间固定，从 $\theta^{(0)} = \theta$ 出发，以当前策略收集 $\mathcal{D}_c^{(0)}$。对于有限时域折扣回报，令 $L_c(\theta) = -\mathbb{E}[\sum_{t=0}^{H-1} \gamma^t r_t]$；终端价值取 0。沿用策略梯度的可微性、环境不依赖策略参数及可积性条件，可构造

$$\widehat{\boldsymbol{g}}_c = -\frac{1}{N}\sum_{j=1}^{N}\sum_{t=0}^{H-1}\gamma^t \nabla_\theta \log \pi_\theta(a_{j,t} \mid h_{j,t})\big(G_{j,t} - b(h_{j,t})\big),$$
$$\theta' = \theta - \alpha\widehat{\boldsymbol{g}}_c. \tag{6.10}$$

$G_{j,t}$ 是轨迹 j 从动作时刻 t 起的折扣回报，基线 b 不能依赖当前所采动作，且在此梯度中视为固定。式中额外的 γ^t 来自起点目标的折扣；损失是负回报，所以减去负回报梯度才对应提高回报。该样本梯度可记作 $\nabla_\theta \widehat{L}_c$，但不能通过把环境奖励当成参数的普通可微函数来获得它。

示例 6.5　一次目标任务参数更新　将导航末端岔路简化为独立单步教学任务：向右奖励 1、向左奖励 0，动作概率为 $p_\theta = \pi_\theta(\text{右}) = \sigma(\theta)$，初值 $\theta = 0$，基线 0。收集 4 次独立试验，假设实际抽到 3 次右、1 次左。对于右动作，$\partial_\theta \log p_\theta = 1 - p_\theta = 1/2$；左动作奖励 0，贡献为 0。于是

$$\widehat{g} = -\frac{3(1/2)}{4} = -\frac{3}{8}, \qquad \alpha = 2, \qquad \theta' = \frac{3}{4},$$
$$p_{\theta'} = \frac{1}{1 + e^{-3/4}} \approx 0.6792.$$

更新前的真实期望回报为 0.5，更新后为 0.6792。这里能够直接算真实值，是因为教学任务的奖励模型已完整给出；实际未知任务需要

机制	信息存储位置	变化内容	重置与可逆性	主要代价
上下文适应	历史窗口、循环状态	新经验与压缩记忆	可清空；截断丢失的信息未必可恢复	记忆存储、序列前向
任务信念	离散概率或后验参数	各假设的相对可信度	可重置先验；恢复旧后验需保存证据或快照	似然、归一化或近似推断
参数适应	策略、价值或模型权重	梯度及优化器状态	有初值快照才可完整回滚	前后向、优化器、再评价

表 6.7 新任务信息的存储位置。这是机制比较而不是互斥分类：后验可作为上下文输入，记忆更新也可与参数更新同时执行。

> 另采评价数据。4 条记录的经验回报 0.75 既不是更新前真实值，也不能作为更新后性能证明。

执行顺序因此是收集、估计、更新、另行评价。扩展为 K 步时，用 $\theta^{(k+1)} = \theta^{(k)} - \alpha_k \hat{\boldsymbol{g}}_c^{(k)}$；每步若按同策略估计，需要新策略的数据，复用旧数据则必须采用适当离策略估计并满足覆盖条件。固定日志不提供未记录动作的反事实回报，允许梯度计算也不会自动补齐这一缺口。

第 6.4.4 节的 MAML 外循环还需评价更新对初始化的依赖。保留 $\boldsymbol{I} - \alpha\nabla^2\hat{L}_c$ 是在给定内层样本时反传内循环导数；一阶近似以 $\boldsymbol{I}$ 代替这一 Jacobian，减少高阶自动微分开销。二者都还需交代强化学习采样分布项是否纳入估计，不能只因使用了二阶自动微分就声称得到精确随机元梯度。部署时执行若干普通目标梯度步，本身并不需要再计算元梯度。

表 6.7 按新信息写入的位置比较适应机制。计算成本包括训练所需的反向传播、优化器状态和独立评价，而不只是最终策略推理。

少样本梯度方差大，过大步长会破坏原有行为；模型错配或离策略权重过大还会使估计方向失真。教学例中的一次改进不能推成一般单调保证。没有目标更新数据、只获准固定参数部署，或探测动作违反可行动作约束时，就不能默认运行这套流程。

6.5.5 持续交互下的任务辨识与在线适应

未知风向固定不变时，早先的有效观测仍然指向当前任务。持续交互可以逐渐减少不确定性，但前提是所选行为确实带来区分性证据。一直沿安全边界走、从不经过受风影响的位置，可能取得稳定回报，却永远无法辨认风向。

把这一取舍简化为独立的两阶段、不折扣教学任务。两种风先验各半；终端安全路线奖励 0.6，按正确风向选择的捷径奖励 1、选错奖励 0。直接选择时，捷径期望 0.5，故安全路线较好。若第一阶段允许付出 0.1 奖励成本，执行一个正确率 0.8 的对称风向探测，再按信号选择捷径，则总期望

回报为 $-0.1 + 0.8 = 0.7$。不探测的策略在第一阶段等待且不扣分，两者使用相同两阶段时域。探测提高了终端决策的期望回报 0.2，付出成本 0.1，净收益 0.1；若探测成本改为 0.3，原方案就不再值得。

这说明信息收益必须通过后续决策评价，不能仅以任务分类准确率评价。在线过程可以是每收集一小批转移便更新一次后验和策略，也可以逐步更新记忆、偶尔更新参数。共同结构是当前任务信息决定行为，行为决定新数据，新数据再更新任务估计或控制规则。只更新后验、只更新参数、同时更新两者，都可能形成闭环，但代价和稳定性不同。

图 6.9 刻意把任务辨识误差和控制回报画在两个坐标系中。早期误差较大，策略改进受到信息不足限制；后来误差已经很低，回报仍未达到目标，提示还需改善规划或控制。图中的解析曲线仅用于区分两种诊断，不是任何方法的收敛率，也没有假设分类误差可以直接换算成回报。

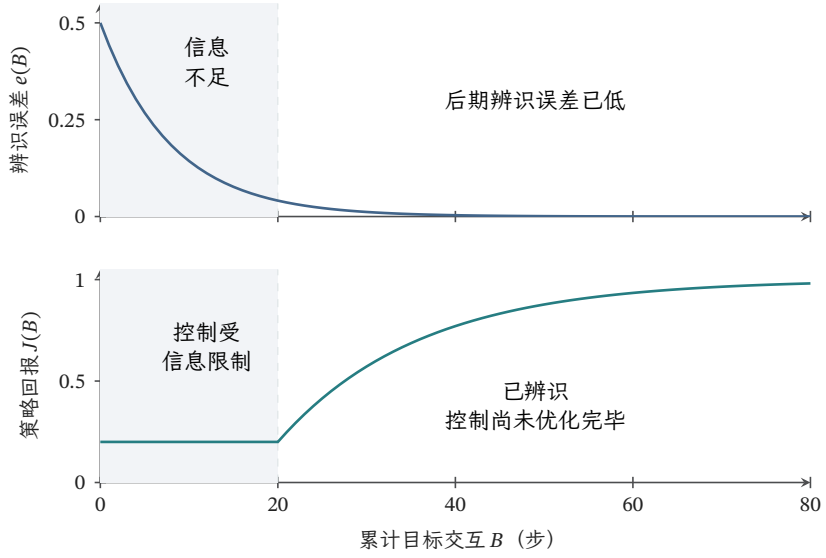


图 6.9　固定任务下辨识与控制的不同进度。教学解析曲线为 $e(B) = 0.5e^{-B/8}$ 和 $J(B) = 0.2 + 0.8(1 - e^{-\max(B-20,0)/16})$；$B$ 为累计目标交互步数。竖线 $B = 20$ 用于分区说明，非实测拐点，亦非理论阈值。两图共享横轴，不共享纵轴量纲。

误差可以按已知测试标签计算，也可以按后验对真实任务的概率或参数偏差计算，报告时需固定一种定义。部署系统没有真实标签时，只能检查预测残差、校准或其他可观察证据；不能把测试者知道的风向反送给策略。实际测量还应改变探测预算，分别检查信息是否改善，以及相同信息下控制优化是否改善。

探测、回到测试位置、失败恢复和再评价全部消耗资源。更多交互只有在可识别、能到达相关状态且反馈权限充分时才有帮助。若辨识需要越过禁止区域，不能以“学习所必需”为理由默认开放动作；安全探索与约束可行性见第 8 章。

6.5.6 任务持续变化下的跟踪与适应

现在把固定风向改成回合间突变，或让风强度缓慢漂移。上个回合的右偏仍是真实记录，却可能不再代表当前风向。直接把式 (6.8) 用于全部历史，会把已失效的证据累积成过度自信；要继续作贝叶斯推断，需要额外给出任务变化模型，否则应采用明确的跟踪估计。

变化检测与重启先检查预测残差是否异常，再丢弃或下调旧模型；滑动窗口只保留最近 W 条记录；历史降权给年龄为 j 的样本权重 λ^j，其中 $0 < \lambda < 1$。窗口大或 λ 接近 1 时，稳定阶段估计方差较低，变化后的响应却较慢。例如独立 Bernoulli 观测在固定参数下，窗口均值的方差为 $\eta(1-\eta)/W$；参数突变后，这个均值在旧记录移出前仍混合两种机制。检测阈值也要在误报、漏报和延迟间取舍。

为明确比较对象，考虑共同有限状态动作空间、共同初始分布 ρ_0 的回合式任务序列。第 k 回合的 MDP 为 $\mathcal{M}_k$，在该回合内固定，时域为 H；本节用不折扣总奖励 $V^{\pi}_{k,0}(\rho_0) = \mathbb{E}_{\rho_0,\pi,\mathcal{M}_k}[\sum_{t=0}^{H-1} r_{k,t}]$，终端价值 0。$r_{k,t}$ 仍按回合内动作时刻编号，与无限折扣目标分别使用。令 π_k 是算法基于此前信息选择的本回合行为规则，可以在回合内依靠新历史行动。

定义 6.6　动态遗憾与静态遗憾　对 T 个回合，动态遗憾取每回合知道当前 MDP、但不知道未来随机结果的最优策略作比较：

$$\mathrm{DReg}_T = \sum_{k=0}^{T-1} \left[V^{*}_{k,0}(\rho_0) - V^{\pi_k}_{k,0}(\rho_0) \right]. \tag{6.11}$$

相对于预先规定的固定策略类 $\Pi_{\text{固定}}$，静态遗憾为

$$\mathrm{SReg}_T = \max_{\pi \in \Pi_{\text{固定}}} \sum_{k=0}^{T-1} V^{\pi}_{k,0}(\rho_0) - \sum_{k=0}^{T-1} V^{\pi_k}_{k,0}(\rho_0). \tag{6.12}$$

固定比较策略不随回合改变，可依赖回合内时间与允许观测；不能暗含当回合隐藏任务标签。随机任务序列或随机算法下，另对这些随机性取期望。

动态比较者在每次变化后都立即知道新的奖励与转移，显著强于部署者。静态比较者只选一个共同规则；算法若成功跟踪变化，甚至可能优于它，故静态遗憾不应解释为适应延迟。两者必须使用相同初始分布；如果还改变初始分布，应把它列入变化机制和评价条件。

次线性动态遗憾需要约束环境变化或赋予额外信息。例如可限制相邻回合任务改变的次数 $S_T = \sum_{k=1}^{T-1} \mathbb{I}\{\mathcal{M}_k \neq \mathcal{M}_{k-1}\}$，或者在共同有界奖励尺度下定义

$$
\begin{aligned}
B_R &= \sum_{k=1}^{T-1} \sup_{s,a} |R_k(s,a) - R_{k-1}(s,a)|, \\
B_P &= \sum_{k=1}^{T-1} \sup_{s,a} \|P_k(\cdot \mid s,a) - P_{k-1}(\cdot \mid s,a)\|_1 .
\end{aligned}
\tag{6.13}
$$

变化次数、累计幅度与单次最小可检测幅度不是同一个量。频繁微小漂移可以次数多而累计幅度小；一次大跳变也可能因相关状态不可达而难以检测。是否给出变化提示、提示是否含新任务参数，以及是否已知变化预算，都需单独说明。相应非平稳学习理论是在这些条件下研究性能，而非取消所有条件后承诺及时适应[16]。

[16] C.-Y. Wei, H. Luo, *Non-stationary Reinforcement Learning without Prior Knowledge: an Optimal Black-box Approach* In Proceedings of Thirty Fourth Conference on Learning Theory, 2021, pp. 4300–4354

定理 6.7　无预告快速变化的两臂下界　在 $H = 1$ 的教学任务族中，每轮 k 独立均匀抽取 $C_k \in \{1,2\}$，动作集合为两个臂，奖励为 $r_k(a) = \mathbb{I}\{a = C_k\}$。选择动作前不给任何关于 C_k 的线索；选择后可以观察所得奖励。对任何使用过去历史并可随机化的算法，

$$
\mathbb{E}[\mathrm{DReg}_T] = T/2.
$$

证明　令 $\mathcal{F}_k$ 包含第 k 轮之前的全部动作、奖励及算法已用的随机数。算法还可使用与任务序列独立的新随机数 U_k，据 $(\mathcal{F}_k, U_k)$ 选择 A_k。由构造，C_k 与这两项信息独立且均匀，因此不论条件动作概率如何，对条件概率为正的动作 a，$\mathbb{P}(C_k = a \mid \mathcal{F}_k, U_k, A_k = a) = 1/2$。对动作分支求和便得

$$
\begin{aligned}
\mathbb{P}(A_k = C_k \mid \mathcal{F}_k, U_k) &= \sum_{a=1}^{2} \mathbb{P}(A_k = a \mid \mathcal{F}_k, U_k)\, \frac{1}{2} \\
&= \frac{1}{2}.
\end{aligned}
$$

取全期望，每轮算法的期望奖励为 $1/2$。知道当前任务 C_k 的动态比较者选择臂 C_k，每轮奖励恒为 1；它不需要预知任何未来任务。由期望的线性性，

$$
\mathbb{E}[\mathrm{DReg}_T] = \sum_{k=0}^{T-1} (1 - \mathbb{E}[r_k(A_k)]) = \sum_{k=0}^{T-1} (1 - \tfrac{1}{2}) = T/2.
$$

轮未反馈即使揭示了本轮完整任务，也不能预测独立的下一轮，所以结论不依赖算法的记忆容量、计算时间或参数更新能力。 ■

这一下界不否认缓慢变化可以跟踪，也不否认预告信号可以帮助决策。它只指出：比较者知道当前最好动作而算法在选择前毫无线索时，无规律快速变化本身足以产生线性代价。静态比较者的期望优势却小得多。令 N_1 为 T 轮中臂 1 高奖励的次数，最佳固定臂奖励为 $T/2 + |N_1 - T/2|$；由方差及 Cauchy–Schwarz 不等式，$\mathbb{E}|N_1 - T/2| \le \sqrt{T}/2$。因此同一算法对固定臂的期望静态遗憾至多 $\sqrt{T}/2$，而动态遗憾仍是 $T/2$。换比较对象就换了结论。

图 6.10 进一步区分变化发生、变化检测和性能恢复三个时刻。检测准确也不等于立即恢复：模型重估、规划与控制学习仍有代价。恢复阈值和观察窗口应提前规定，不能看到曲线后再选最有利时刻。

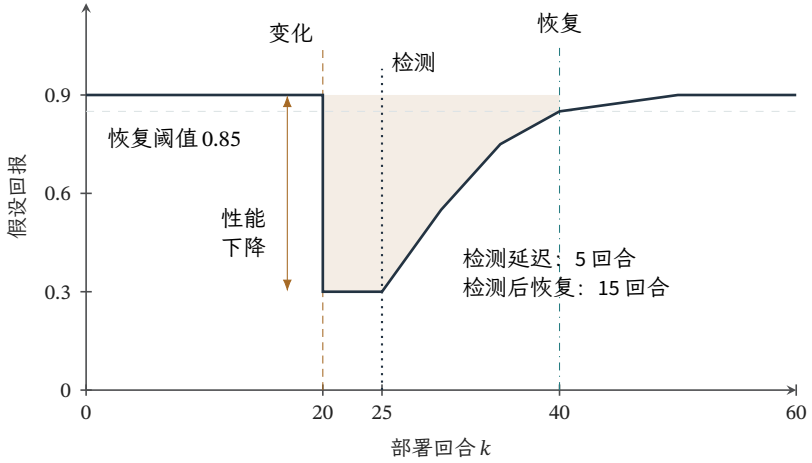


图 6.10　变化、检测与恢复的教学时间线。曲线由图源中给定的分段线性控制点生成；变化在回合 20，检测在 25，首次达到预设回报阈值 0.85 在 40。下降、延迟和恢复期间的差额各有含义，非任何算法的实测轨迹。

若系统从不按回合重置，前期动作会影响变化发生时的物理状态，就应使用适合持续过程的平均回报、动态比较规则或跟踪损失，不能原样套用共同 ρ_0 的式 (6.11)。本节关注变化期间的决策代价；旧能力保留、遗忘和一般持续学习理论属于第三卷“知识的演进与迁移”部分。

6.5.7　任务信息与适应权限的组合边界

显式描述、记忆、梯度更新与持续交互可以出现在同一系统中。目标坐标已知，只排除了目标身份的不确定性；陌生地面仍可能要求估计摩擦参数。隐藏风向没有描述，也不意味着必须改网络权重：记忆中积累的偏移证据足以改变条件策略。

表 6.8 以信息条件为行、机制权限为列。每格写的是该组合所需的证据和接口，而非给方法贴一个永久类别标签。

信息条件	零样本调用	上下文更新	参数更新	持续交互
显式描述	描述语义、范围与接口兼容；不读目标反馈学习	描述加获准历史；反馈可补描述遗漏	描述加日志或新样本；允许反传	允许探测描述未给出的动力学；全部计费
隐藏任务	只能基于先验或已有信息选择；不可假装知道任务	历史须含区分性反馈；规定窗口与重置	更新样本须支持估计；不使用隐藏标签	可达的区分动作、反馈权限与恢复预算

表 6.8 任务信息与适应权限的组合。各列可同时启用，持续交互是一种数据权限，不是与记忆或梯度互斥的网络结构。

例如，显式目标加两步梯度更新可以用目标选择损失，再由新转移修正行动者；但两步所用交互、学习率选择和更新后评价仍须纳入预算。隐藏风向加固定参数记忆则可用第一回合判断风向、第二回合选路；它不消耗梯度步，却消耗反馈和上下文。两种组合只有在总交互及允许信息可比时，才有理由比较“适应更快”。

技能复用也遵循这一划分。任务描述或信念决定高层在合法启动集内选哪项技能，技能结束后根据新观测再组合下一项；若允许更新，可以只改高层选择器，也可以调整技能内部控制参数。后者可能改变持续时间与终止分布，应重新检查与高层价值估计的接口，而不能把内部更新当作无影响替换。技能定义与单任务时间抽象仍沿用第 3 章。

比较方法前应同时固定目标交互数、反馈字段、上下文容量、梯度步数及额外计算。主动辨识与基于测试成绩的选模都使用目标信息，不能从预算中删除。适应机制的组合越灵活，实验协议越需要明确。

6.6 迁移结论的验证与修正

前面给出了哪些知识可能共享、目标任务提供什么信息，以及策略如何形成。验证要将这些条件变成可执行协议：任务从哪里来，哪些反馈在何时可见，结果与哪种比较对象相对。否则一个较高分数无法说明究竟是哪项迁移主张得到了支持。

6.6.1 由目标任务适用范围确定任务级数据划分

要检验支持内新任务，应把完整任务身份留出；要检验组合泛化，应留出目标与噪声的指定组合；要检验范围外能力，应把相应因素范围从训练和调参任务中排除。若只把同一风向、同一目标下的轨迹随机分成两组，测试的仍是任务内新经历，不是跨任务泛化。

图 6.11 按任务、回合、片段三层展示这一差别。同一回合的相邻片段共享物理轨迹，同一任务的不同回合共享隐藏参数；把它们都视为独立任务会严重夸大证据量。

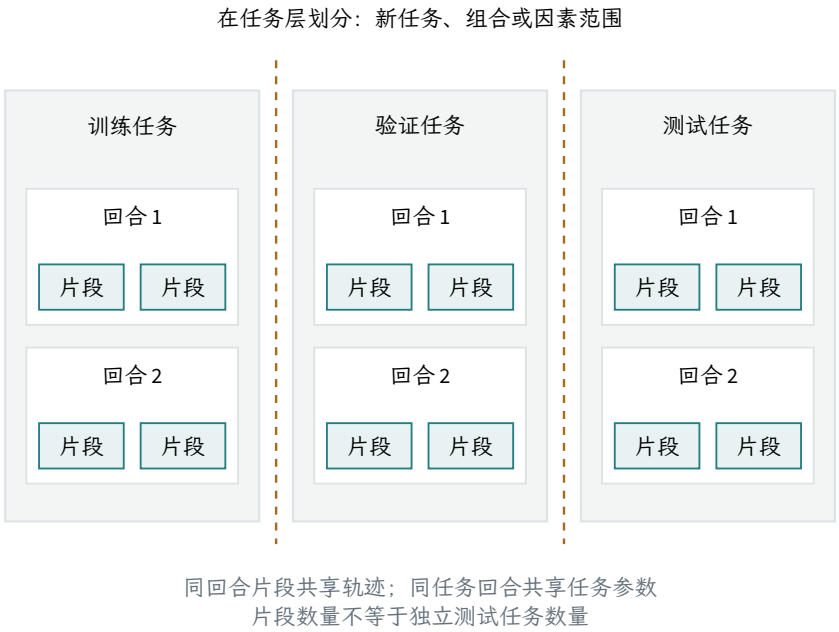


图 6.11　任务级划分与任务内采样。训练、验证、测试先按所声明的任务关系划分，再在每项任务内采集回合和片段；同色框中片段共享任务参数，不能按片段数声称独立任务数。图为抽样层级示意，不对应某个数据集规模。

例如，三个独立生成的风向任务各采 10 回合，每回合切 20 段，共有 600 个片段，但任务层独立单位仍只有 3 个。这些是教学计数。若要评估任务平均回报的不确定性，应在任务层重采样，或用明确的分层统计模型；训练种子另是模型训练随机性的层级，不能将同一个训练种子下的 600 段当作 600 次独立训练。

测试协议应预先固定是否允许交互、奖励到达时刻、回合结束与任务切换的记忆重置，以及检查点数量。非平稳测试还要固定任务时间顺序；打乱时间后进行批量拟合，使用的是另一种信息权限。不能让策略提前看到未来风向标签，也不能在恢复时间统计中删除失败回合。

泄漏不只来自重复轨迹。程序化生成器可能只更换纹理而复用同一路线模板，共享随机种子可能重现测试布局，目标描述可能直接包含最优动作编码。应检查生成器结构、种子谱系和描述字段。允许在一项测试任务内按既定协议适应，不等于允许根据整套测试成绩反复重设计训练方法；后一种选择应在验证任务上完成。

6.6.2　在任务划分与固定预算下取得性能证据

初始行为、学习过程和学习完成后的策略回答不同问题。令 c_i 为第 i 个测试任务，$\pi_{i,0}$ 为未使用该任务更新数据时的策略；$\pi_{i,B}$ 为按协议使用 B 步反馈后形成的策略。若使用本章前面的无限折扣任务，回报仍为未归一化 J_{c_i}；若评价固定长度回合，则另注明时域、折扣和截断规则。

比较对象	已有知识与信息	目标预算	解释范围
从头学习	随机初始化，不用源任务知识	相同 B,K,L,C，独立评价另计	共享训练是否减少目标学习代价
无适应	相同源模型，关闭任务更新	适应交互 0、梯度 0；执行预算相同	初始能力与适应带来的变化
单任务训练	不共享参数的指定任务训练	报预训练量；目标比较仍匹配 B,K,L,C	共享收益与容量、训练量差异
已知任务身份	额外给真实任务参数	其余预算匹配，信息权限另标	知情参考；训练策略未必是上界
可证明最优值	完整已知模型或可证明的信息松弛	比较者权限显式列出	条件成立时才是性能上界

表 6.9 性能证据需要的参照对象。“无适应”是刻意关闭反馈学习的消融，不能假装它花掉了与适应方法相同的学习预算；单任务参考若用目标数据预训练，必须披露这项额外信息。

零样本回报为 $n^{-1}\sum_i J_{c_i}(\pi_{i,0})$。**适应后回报**为 $n^{-1}\sum_i J_{c_i}(\pi_{i,B})$，需要固定适应所得参数与任务信息、在独立评价回合上估计，并另报这部分交互数。评价时仍可按协议更新控制所需的物理状态估计，但不继续辨识任务；若一个记忆器无法分开这两项功能，就应明确评价中仍在适应。**预算内适应曲线**则记录随着累计目标交互增加，当前在线回合实际取得的回报，或在指定检查点另测的回报；这两种曲线不能混标，后者的查询成本也不能省略。

为评价学习期间的损失，固定同一目标任务、同一回合时域与初始分布，取指定比较策略 $\pi_i^{\text{参照}}$。用 $\pi_i^{(k)}$ 表示第 k 个适应回合的行为规则，区别于使用 B 步反馈后的 $\pi_{i,B}$。在 M 个适应回合中定义

$$\mathrm{AReg}_{i,M}=\sum_{k=0}^{M-1}\left[J_{c_i}(\pi_i^{\text{参照}})-J_{c_i}(\pi_i^{(k)})\right]. \tag{6.14}$$

若比较者只是一条训练得到的策略，该量可能为负，名称不赋予其最优性；必须写出参照者及信息权限。对于任务本身变化的情形，应另用式 (6.11) 及检测、恢复指标，不能把固定 c_i 的本式直接改个标题。

表 6.9 给出比较协议。B,K,L,C 分别表示目标适应步、梯度步、上下文长度和额外计算上限；它们是符号预算，不是某篇论文配置。共享训练的前期成本也应报告，即使目标任务比较只匹配部署预算。

图 6.12 给出一个完全可复算的教学汇总。设目标任务 $i=1,\dots,5$、训练种子 $j=1,\dots,3$，定义假设回报

$$\begin{aligned} y_{i,j}(B)&=0.2+0.7(1-e^{-B/30})+u_i e^{-B/60}+v_j,\\ u_i&\in\{-0.16,-0.08,0,0.08,0.16\},\\ v_j&\in\{-0.02,0,0.02\}. \end{aligned}$$

此处所有数值都是作者设定的回报尺度；每条曲线是给定公式，不是实验测量。先对种子平均，再对任务平均，得到均值 $m(B)=0.2+0.7(1-e^{-B/30})$。

阴影取种子平均后任务分数的均值加减一个样本标准差，即 $s_{\text{任务}}(B) = \sqrt{0.016\, e^{-B/60}}$，不是均值的置信区间。实际实验还需估计评价回合随机性，并说明任务与训练种子的嵌套或交叉方式。

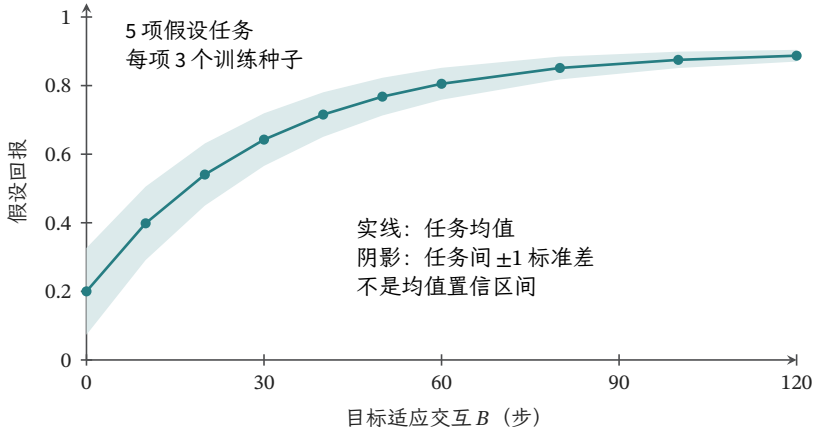


图 6.12 固定预算下均值与任务间离散程度的教学曲线。横轴为目标适应交互步数，纵轴为假设回报；线为 5 任务、3 训练种子的等权均值，阴影为先平均种子后的任务均值 ±1 样本标准差。图源按正文公式在所列检查点计算并线性连接，无算法实测排名；真实协议中的评价交互还须单独计入。

不同任务的回报尺度不同时，可以分别报告原始分数，或使用预先固定、具有解释意义的参照范围归一化；归一化分母接近 0 的任务需要单独处理。不能观察测试结果后选择有利的缩放方法。汇总还应报告各任务组的失败比例、差异幅度及不确定性，避免少数高分任务掩盖多数任务无收益。训练得到的知情策略即使表现很好，也只有参考意义，不能未经证明称为最优上界。

6.6.3 从迁移结果到共享假设的诊断与修正

相对于明确的不共享或从头学习基线，在相同目标信息与预算下，提高指定评价指标称为**正迁移**（positive transfer），降低则称为**负迁移**（negative transfer）。这里的正负依赖任务组、指标和预算：学习早期有益、最终性能稍低，可以同时成立。不能把一次更高的样本均值直接写成稳定的正迁移结论。

考虑四项等权教学任务，基线回报均为 0.6，共享模型回报分别为 $0.8, 0.8, 0.8, 0.2$。共享均值为 0.65，平均提高 0.05，第四项任务却下降 0.4。若第四项恰好使用未覆盖的左风，这一结果提示检查任务分层与覆盖；它本身尚不能证明动力学共享假设错误。

诊断需要补充可以区分解释的证据。数据覆盖不足时，应控制任务采样和相关状态动作访问；表示容量不足时，应比较参数量和计算量匹配的模型，并检查目标信息是否被丢弃；优化冲突时，可比较分任务梯度的内积、独立训练与任务权重调整。负梯度内积只是局部冲突信号，不自动说明两

个任务在真实结构上不兼容。要检验共享结构，可保持其余训练条件，替换被怀疑的共同模块为任务条件或独立模块，并在受影响任务组上重新评价。

图 6.13 将修订对象分开。匹配容量后仅改变任务权重便恢复性能，更支持训练机制解释；在充分覆盖与多种优化设置下，共享转移模块仍系统性地把相反风向混合，而任务条件模块消除了相应预测误差，才为重新检查共享假设提供较直接的证据。

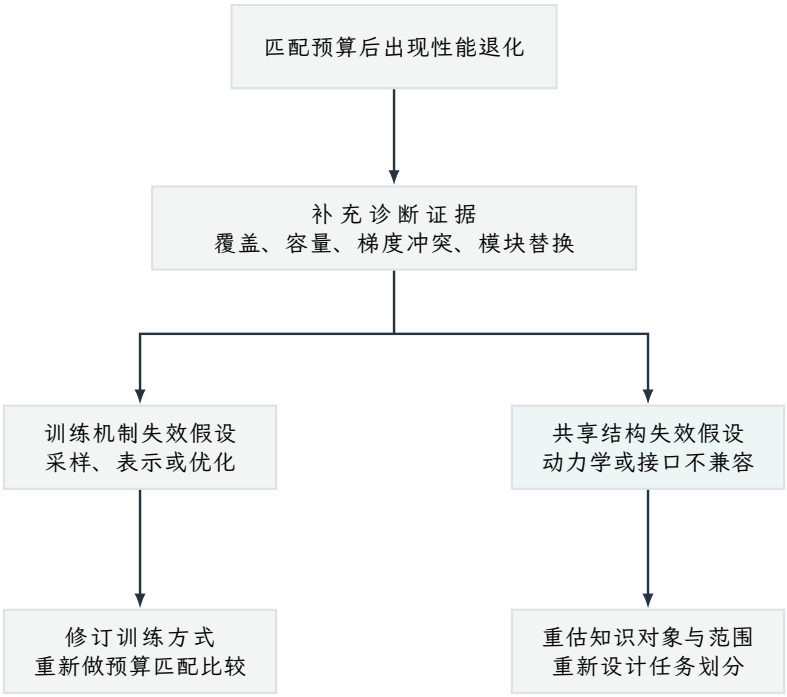


图 6.13　由退化结果形成可区分的诊断。分支表示待检验解释，不能只凭一次失败直接确定根因；训练问题修订采样、容量或优化，结构问题则重估共享对象及适用任务。图为本章诊断关系的原创示意。

单一基线可能容量不足，一次种子可能恰好失败，模块替换也可能同时增加容量。因此需要逐项控制差异，报告重复试验与不确定性，而不是见到改进就倒推唯一原因。共享结构一旦改变，原来的任务支持与组合假设也要重查，不能沿用旧条件下的泛化声明。

6.6.4 由评测证据限定泛化与适应声明

一个可检查的迁移声明至少包含目标任务关系、可用信息、适应预算和性能证据。省去其中任何一项，都可能把更容易的实验解释成更强的能力。表 6.10 汇总本章导航变体分别能够支持的说法；表中的结论以相应实验确实取得可靠证据为前提，本章教学数值本身不构成算法实验证据。

目标任务关系	可用信息	适应预算	评价证据	允许的结论
支持内新目标	兼容的目标坐标	无反馈适应	任务级留出零样本回报	声明总体内的描述条件泛化
未见目标与风组合	相同描述字段	固定 B, K, L, C	留出联合组合的分组结果	指定因素与组合上的能力
未见噪声范围	描述或获准历史	明确探测与更新	范围外分组、失败与误差	已测范围内的外推证据
固定隐藏风向	无真实风标签，反馈逐步可见	探测、恢复、评价均计	辨识误差、适应回报与参照差额	规定信息条件下的固定任务适应
变化风向序列	不提前见未来变化	按时间顺序持续交互	动态遗憾、检测延迟与恢复	指定变化预算及信号下的跟踪

表 6.10 证据与声明的对应关系。支持内、组合、范围外、固定隐藏任务和变化任务不是逐级自动推出的能力；每一行都需要自身的任务划分与协议。

训练任务数量很大，但每项只改变同一地图的颜色时，测试高分仍不能证明新几何泛化。目标和风向都单独测过，但从未共同改变时，不能推断组合有效。若变化检测器提前读到了下一回合任务标签，快速恢复也不能支持无预告持续适应。这些反例没有否认已测分数，而是限定分数回答的问题。

还应区分平均能力与最低要求。对声明任务分布取得较高平均回报，不等于在所有允许扰动下都不低于某个阈值；后者需要明确扰动集合、风险或最坏情形准则，以及相应验证。鲁棒性与可信保证留到第 8 章讨论，不能由本章经验泛化结果直接推出。

6.7 本章小结

回到章首的小车：换目标时，共同移动规律可能继续使用，价值却要按新奖励重算；地面变滑时，目标含义仍在，旧后果预测却可能失效。判断能否迁移，需要把复用对象与共享条件成对说明，再检查新任务是否属于这些条件覆盖的范围。参数形状相同、平均回报相近或任务编号相邻，都不能替代这一步。

训练阶段形成表示、模型、价值、策略初始化和技能；部署阶段根据描述、历史与权限形成具体策略。固定参数仍可在记忆中适应，参数更新仍需有效数据，持续交互也只有在反馈可识别且动作获准时才补得上信息。后继特征的价值分解依赖共同动力学与奖励特征，GPI 比较的是已有策略，贝叶斯任务更新依赖固定任务和正确似然；这些条件说明每项机制解决了哪一部分问题，也留下了哪些工作。

认识固定未知任务与追踪变化任务并不相同。每轮独立变化的两臂例子表明，计算或记忆无法补出缺失的当轮信息。任务级划分、完整预算、匹配比较者和分层失败诊断，共同约束泛化与适应声明。伙伴与对手也会

带来任务变化，但各自的目标与共同学习需要联合建模。第 7 章将考察这些依赖，并把任务信息与适应预算的约定用于交互双方。

第 7 章

多智能体协作和博弈

两个人从窄通道的两端相向而行。一人决定前进，如果另一人等待，通道便能放行；如果另一人也前进，两人可能堵在入口。这里没有改变通道的物理规则，改变的只是另一个决策者的行为。单智能体价值学习仍能计算长期后果，却不能独自回答三个问题：谁的收益应当增加，行动时究竟能知道什么，以及对方会不会随着自己的变化而调整策略？

本章沿用第1章的策略、回报和价值，以及第3章的采样与更新工具。多个参与者带来的新困难，不只是联合动作空间变大，还包括信息分散、目标冲突和共同学习。图7.1给出这些问题的联系：收益关系规定行为标准，信息权限限定可实现策略；联合经验支持后果估计，策略更新又改变经验来源。估计时可以同时使用联合价值、反事实基线和伙伴模型；更新时也可以同时采用策略梯度、历史响应和策略群体。这些选择不能排成互斥算法的演进链。

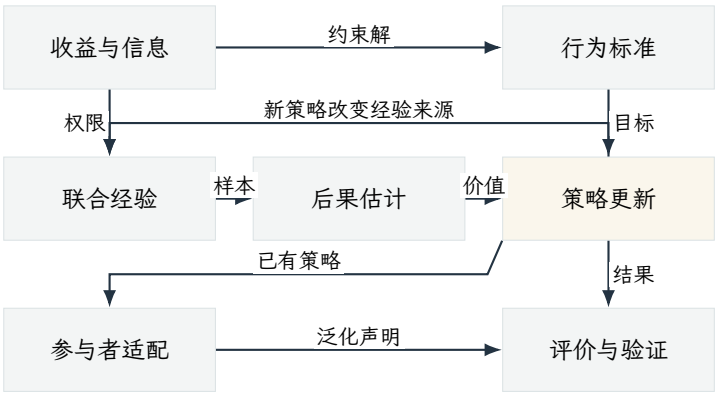


图 7.1　本章的问题关系。实线标出约束、数据或估计的用途，外侧回路表示更新后的策略改变经验；底部的适配与评价检验的是声明的参与者范围和行为标准。

7.1 收益、信息与参与者的共同设定

7.1.1 用联合动作、转移与个体回报定义决策过程

先把窄通道压缩成一个可手算的教学任务。两人尚未通过时处于状态 $s_{\text{入口}}$，每人可选前进 F 或等待 W。(F,W) 使第一人通过，(W,F) 使第二人通过；随后未通过者再前进一步，两人都到达吸收终点。(W,W) 保持原位，(F,F) 也保持原位并记一次碰撞。这是确定性简化，不是前几章随机网格的数值解。若每步时间成本为 -1，碰撞另扣 3，第一人在入口前进的即时收益便随对方行为从 -1 变成 -4。

定义 7.1　多参与者序贯决策　参与者集合为 $\mathcal{N}=\{1,\dots,m\}$，$-i$ 表示除 i 以外的参与者。联合动作为 $\boldsymbol{a}=(a_1,\dots,a_m)\in\prod_i \mathcal{A}_i(s)$。共同转移核为 $P(s'\mid s,\boldsymbol{a})$，参与者 i 的期望奖励为 $R_i(s,\boldsymbol{a})$。局部历史 $h_{i,t}$ 记录 i 在动作 t 之前获准使用的观测、自身动作、可见奖励和已收到的消息，策略 $\pi_i(a_i\mid h_i)$ 据此选择动作。联合策略记为 $\boldsymbol{\pi}$，其未归一化折扣目标为

$$J_i(\boldsymbol{\pi})=\mathbb{E}_{\rho_0,\boldsymbol{\pi}}\left[\sum_{t=0}^{\infty}\gamma^t r_{i,t}\right],\qquad 0\le\gamma<1.$$

若给定联合历史 $\boldsymbol{h}$ 后各人独立随机化，则 $\boldsymbol{\pi}(\boldsymbol{a}\mid\boldsymbol{h})=\prod_i\pi_i(a_i\mid h_i)$。若在该历史后广播公共随机信号 c，只在给定 c 后作乘积分解；边缘联合分布是 $\sum_c p(c\mid\boldsymbol{h})\prod_i\pi_i(a_i\mid h_i,c)$，通常不等于各边缘分布的乘积。随机博弈（stochastic game）用共同状态和转移把矩阵收益关系延伸到多步决策，其经典完全可观测形式由 Shapley 建立[1]。

[1] L. S. Shapley, *Stochastic Games* In Proceedings of the National Academy of Sciences, 1953, vol. 39, no. 10, pp. 1095–1100

在其他参与者使用固定的状态条件策略，且给定 s 后其联合动作与 i 的动作独立随机化时，参与者 i 可以把他们的动作边缘化：

$$P_i^{\pi_{-i}}(s'\mid s,a_i)=\sum_{\boldsymbol{a}_{-i}}\boldsymbol{\pi}_{-i}(\boldsymbol{a}_{-i}\mid s)P(s'\mid s,a_i,\boldsymbol{a}_{-i}),\tag{7.1}$$

$$R_i^{\pi_{-i}}(s,a_i)=\sum_{\boldsymbol{a}_{-i}}\boldsymbol{\pi}_{-i}(\boldsymbol{a}_{-i}\mid s)R_i(s,a_i,\boldsymbol{a}_{-i}).$$

例如，对方在入口以概率 q 等待，自己前进后的通过概率就是 q，即时期望收益为 $-4+3q$。对方把 q 从 0.8 改成 0.2，通过概率与收益随之改变，但 P 和 R_i 并未改变。共同学习的非平稳性可以产生于这个边缘化过程，而不必来自物理环境漂移。

式(7.1)不要求其他人彼此独立，却要求 $\mathbb{P}(\boldsymbol{a}_{-i}\mid s,a_i)=\boldsymbol{\pi}_{-i}(\boldsymbol{a}_{-i}\mid s)$。若公共信号使双方动作相关，应把该信号加入条件，再检查这一等式；不能直接用边缘分布替代给定自身动作后的条件分布。对方若根据过去的碰撞次数调整让行概率，仅有当前位置也不足以预测下一动作。此时应把记忆

或类型纳入充分状态，或者在历史上定义过程；不能直接套用平稳 MDP 的收敛结论。

7.1.2 不同收益关系下的合作、零和与一般和问题

在同一入口上可以规定不同目标，而不改变动作空间。完全合作时，两人共享奖励，例如碰撞 -2、都等 -1、恰好一人前进 2。两人零和时，只评价谁先通过：(F,W) 给第一人 1，(W,F) 给第一人 -1，其余为 0，第二人收益取相反数。一般和时，每人承担自己的时间成本，等待者可能比先行者付出更多，碰撞却损害双方。上述数字均是教学设定。

完全合作指所有人的回报目标一致；**两人零和**指每个结果中 $r_{1,t}+r_{2,t}=0$，因而 $J_2=-J_1$；**一般和**允许任意收益关系。团队奖励共享不等于观测共享，也不保证两套独立更新能发现同一种让行约定。表7.1说明，先规定收益关系，才能选择后面要验证的标准。

收益关系	标准与单方偏离	额外社会选择
完全合作	在可行信息下最大化共同 J；单方改动也按共同收益计	若存在多个最优策略，仍需选择兼容约定
两人零和	最大化最坏收益；偏离检验可被利用的程度	价值标准已给定，风险限制可另设
一般和	各自偏离是否获利；可另优化福利	必须另定福利、公平及取舍

表 7.1　固定任务接口，只改变收益关系时的行为标准。一般和没有默认的共同最大化目标。

一般和不是“每人各自最大化，然后把结果加起来”。一个结果可以总收益很高，却使一人愿意立即偏离；另一个结果无人愿意偏离，却让双方都不满意。福利、分配和稳定性回答不同问题，不能靠奖励求和消除它们的冲突。

7.1.3 不同行动、观测与通信时序下的信息结构

通道中的消息“我先走”只有在对方行动前到达，才可能帮助本轮协调。图7.2把观测、发信、收信、行动和反馈分开。同一条消息若延迟一轮，只能进入 $h_{i,t+1}$；训练日志最后收集到了它，并不意味着行动 t 时能够使用。顺序行动也要另作说明：后行动者可能看见先行动作，同时行动者则不能。

程序接口的调用次序也不一定表示可观察的行动次序。PettingZoo 统一了多类多智能体环境的调用接口；其智能体—环境循环（agent environment cycle, AEC）接口依次调用参与者，但实现同时行动任务时，仍须屏蔽本轮其他参与者尚未共同提交的动作[2]。

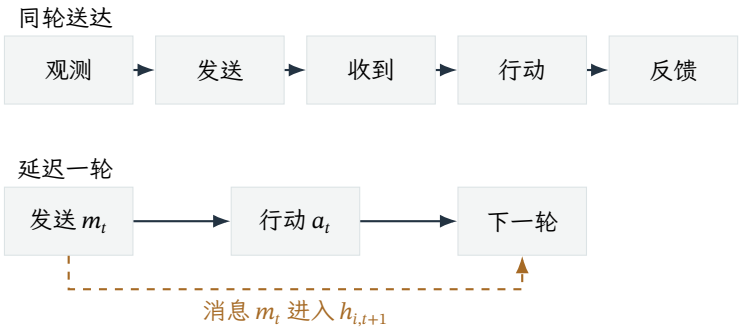


图 7.2 同轮通信与延迟通信的可见时刻。实线表示本轮可用信息，虚线表示下一轮才收到的消息。顺序行动还可开放对先行动作的观测，不能与同时行动混用。

通信内容也会改变可用信息。CommNet 通过连续向量及聚合形成协作输入，让参与者在动作前利用同伴传来的表示；这些表示只有按约定及时送达，才属于本轮策略输入[3]。

部分可观测随机博弈（partially observable stochastic game, POSG）在定义7.1上增加联合观测核 $O(\boldsymbol{o}' \mid s', \boldsymbol{a})$ 及初始观测分布。局部观测 o_i 只是状态生成的一个信号，不等于 s。当各人共享团队奖励，且策略仅使用各自历史时，得到**分散部分可观测马尔可夫决策过程**（decentralized POMDP, Dec-POMDP）。通信可加入动作或显式消息阶段，顺序行动可用状态中的行动者标记表示；任何表示都须保留原信息限制。分散控制的困难不仅是状态不可见，还在于每人不能任意合并他人的信息[4]。

为说明“看不见”如何限制策略，另定义一个有限隐藏牌面游戏。它不是标准扑克规则，以下规则已给出全部随机性与收益。机会方以各 $1/2$ 的概率发高牌 H 或低牌 L 给参与者 1，仅 1 看见牌。两人各先投入一单位。1 可下注 B 或过牌 K；若 1 下注，2 可弃牌 F 或跟注 C。若 1 过牌，2 可过牌 K 或下注 B；若 2 也过牌，立即摊牌；若 2 下注，1 再选择弃牌 F 或跟注 C。此后结束。摊牌时，高牌由 1 赢、低牌由 2 赢；无人加注的摊牌使胜者净得 1，跟注后的摊牌使胜者净得 2，有人弃牌时未弃牌者净得 1。另一人净收益取负值。不设折扣，只有终局收益。

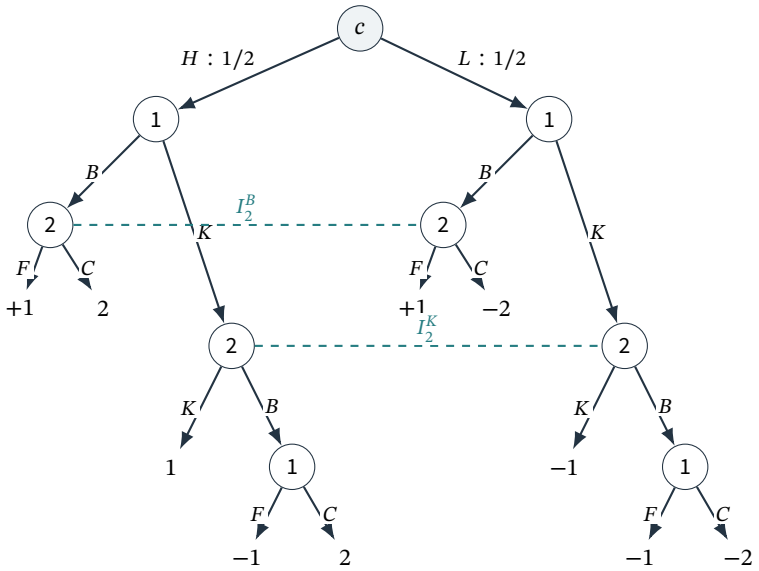
图7.3给出了完整历史树。圆节点是决策，顶部机会节点生成私有牌面，叶节点标第一人的净收益。参与者 2 面对首次下注时，不能分辨高牌分支和低牌分支；这两个节点组成同一**信息集**（information set），即行动者凭现有信息无法区分的一组历史。2 在这两个节点必须使用相同的跟注概率，

[2] J. K. Terry, B. Black, N. Grammel, M. Jayakumar, A. Hari, R. Sullivan, L. Santos, R. Perez, C. Horsch, C. Dieffendahl, N. L. Williams, Y. Lokesh, P. Ravi, *PettingZoo: Gym for Multi-Agent Reinforcement Learning* In Advances in Neural Information Processing Systems, 2021

[3] S. Sukhbaatar, A. Szlam, R. Fergus, *Learning Multiagent Communication with Backpropagation* In Advances in Neural Information Processing Systems, 2016

[4] D. S. Bernstein, R. Givan, N. Immerman, S. Zilberstein, *The Complexity of Decentralized Control of Markov Decision Processes* In Mathematics of Operations Research, 2002, vol. 27, no. 4, pp. 819–840

否则策略就偷看了牌。2 在观察到过牌后处于另一个信息集，不能把“对方已下注”和“对方已过牌”合并。



B 下注，*K* 过牌，*F* 弃牌，*C* 跟注；叶节点为 u_1。

图 7.3 教学隐藏牌面游戏的完整树。虚线分别连接 2 面对下注和面对过牌的信息集；1 知道自己的牌，故其节点不跨牌面合并。叶节点均为 1 的收益，2 取相反数。

完全回忆（perfect recall）要求同一信息集中的历史具有相同的自身过去信息集及自身动作序列，也就是参与者不会忘记自己曾知道什么、做过什么。本游戏满足该条件：1 在“过牌、2 下注”后仍记得牌面与自己的过牌。若错误地把 1 首次行动的节点与“自己过牌后再次行动”的节点合并，即使牌面相同，也抹去了自己的动作历史；这不是另一种压缩实现，而是破坏了完全回忆。后面的 CFR 遗憾分解与平均行为策略公式都依赖这一条件。

7.1.4 信息权限与联合策略表示

训练时可以让服务器看见双方位置和动作，但部署时每人可能只有局部传感器。**集中训练、分散执行**（centralized training with decentralized execution, CTDE）规定的正是这个信息契约：训练器可利用额外信息估计价值，执行策略只能使用当时确实可得的输入。图7.4将集中评论家与局部行动者分开。删除训练专用的状态和梯度线后，图中仍须存在完整的动作生成路径。

若两人的观测、动作和角色语义兼容，可以共享 $\pi_\theta(a_i \mid h_i)$ 的参数；共享的是函数，不是输入观测。身份编码 e_i 使同一网络学习“1 先走、2 等待”，却可能在身份重排后失效。独立参数则允许不同动作接口或角色，但

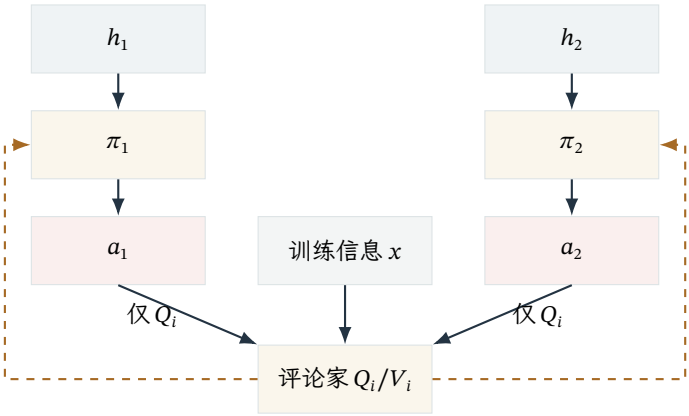


图 7.4 CTDE 的信息与梯度路径。局部历史生成各自动作，集中状态只供训练评论家；虚线是训练梯度，部署时删除。评论家可为联合动作价值 Q_i，也可为不以当前动作为输入的状态价值 V_i。

参数量、训练数据需求和协调搜索空间通常增加。是否使用身份应当服从任务，而不是默认把固定编号当作可迁移的行为特征。

DIAL 在训练时利用可微信道传递梯度，执行时则使用受限的离散消息。训练近似与部署信道并不相同，量化后仍须检查传递的信息是否支持原来的协调行为[5]。

通信还需要一份比“允许发消息”更具体的约定。表7.2中的四种接口都可能与 CTDE 组合；训练中能反向传播消息，并不使部署链路的延迟、带宽和接收权限消失。

接口	发送者、接收者与内容	时序、带宽及训练／执行条件
固定协议	每人向指定邻居发角色或让行码	动作前收信；固定比特数；两阶段协议均保持
可微通信	所有人向聚合器或同伴发实向量	每轮一至多次交换；向量维数固定；执行须保留信道
离散消息	每人向获准接收者发有限字母表符号	训练可用连续松弛；执行量化后重新核验
图消息传递	节点向图邻居发嵌入或定向消息	边数与轮数决定带宽；部署只能使用可发现的边

表 7.2 消息接口的比较。每一行都必须同时确定发送与接收权限、消息内容、送达时刻和通信成本。

接收对象还可以由消息决定。TarMAC 通过定向寻址计算接收权重，使不同接收者聚合不同内容。这一选择作用于“消息给谁”，与前述消息内容和训练信道的选择可以组合[6]。

[5] J. Foerster, I. A. Assael, N. de Freitas, S. Whiteson, *Learning to Communicate with Deep Multi-Agent Reinforcement Learning* In Advances in Neural Information Processing Systems, 2016

[6] A. Das, T. Gervet, J. Romoff, D. Batra, D. Parikh, M. Rabbat, J. Pineau, *TarMAC: Targeted Multi-Agent Communication* In Proceedings of the 36th International Conference on Machine Learning, 2019, pp. 1538–1546

7.1.5　不同数据访问与参与者变化方式下的学习问题

面对固定避让规则，学习者可以通过探索识别其响应；面对共同训练的伙伴，刚识别出的规则下一轮可能已经改变；从历史策略库抽样，则还要知道每场抽到了谁。这三种条件中的参与者数都是二，但经验分布与可验证声明不同。表7.3把数据权限和参与者变化分开，表中“可改变”均指学习者按协议有权改变，不能把第三方对手的主动变化算作自己的采集能力。

参与者条件	在线访问	固定联合日志	有限批次访问
固定伙伴	可改自身行为，伙伴不变	不可重采；还原固定版本	批间改自身，批内固定
同步学习者	可按约定更新双方	仅观察历史更新，不能重放新响应	批间同步更新，批内冻结
群体抽样	可改获准的抽样分布	只能使用已记录群体支持	批间改抽样，批内固定
主动适应者	自身动作可诱发其响应，未必可控	响应机制可能不可识别	须声明对方是否随批内历史更新

表 7.3　数据访问与参与者条件的交叉。有限批次中若对方仍会适应，就不能声称整批由固定联合策略生成。

学习对象可以只有一个策略，也可以是多个策略，只要结果由多方行为共同决定，便需要多智能体建模。反过来，运行多个固定规则代理或多个语言模型角色，并不自动构成多智能体强化学习。还应指出哪个策略在优化、反馈由何种交互产生、更新针对哪个回报；“多人对话”只是交互接口，不是学习目标。

7.2　不同收益关系下的行为标准

“学得更好”必须有比较对象。本节在同一有限两动作接口上分别规定团队最优、最坏情形价值和单方偏离稳定性。它们是不同收益关系下的并列标准，不是一个算法必须依次达到的等级。

7.2.1　共同目标下的联合最优标准

共享回报时，团队希望最大化 $J(\boldsymbol{\pi})$，但最大化必须在实际可执行的策略集合 $\Pi_{\text{分散}}$ 上进行。该集合同时受局部信息、消息时序和公共随机性的限制。训练期间看见更多信息，只能改善求解或估计，并不能自动扩大部署集合。

定理 7.2 集中与分散策略的可行集合 设奖励有界且 $0 \le \gamma < 1$。若集中控制器在每个决策时刻能取得分散系统的全部可用历史，并模拟其私有随机性、公共随机性及合法通信，则每个分散策略都可由集中策略实现相同轨迹分布。按实现的分布识别策略时，

$$\Pi_{\text{分散}} \subseteq \Pi_{\text{集中}}, \qquad \sup_{\pi \in \Pi_{\text{分散}}} J(\pi) \le \sup_{\pi \in \Pi_{\text{集中}}} J(\pi).$$

证明 任选分散策略 π。集中控制器保存每人的局部历史；每一时刻按原协议产生公共信号，再按原联合随机机制生成各人的私有随机数与消息，调用各个 π_i 得到联合动作。初始历史分布与原系统相同。若直到 t 的联合历史分布相同，模拟器在该历史下产生相同的条件动作分布，而环境转移与观测核未变，故 $t+1$ 的联合历史分布也相同。归纳得到全部有限轨迹分布相同；有界奖励和 $\gamma < 1$ 保证折扣回报期望相同。于是每个分散可达回报都能集中实现，对集合取上确界即得不等式。若有限问题中最优策略存在，可将上确界写成最大值。 ■

包含关系可能严格。设一次通行前随机出现公平信号 $c \in \{0,1\}$，团队只有在两人都选择 c 时得 1，其他情况得 0。集中控制器看得见 c，总能得 1；分散双方各自的观测均与 c 独立，不允许互传观测，随机数则独立于 c 及双方观测。即使允许公共随机数，每个人的动作仍与 c 独立，所以

$$\mathbb{P}(a_1 = a_2 = c) \le \mathbb{P}(a_1 = c) = \frac{1}{2}.$$

这个论证不要求联合观测或联合动作与 c 独立，也不从逐个独立推出联合独立。固定都选 0 即可达到上界；若及时广播 c，两人便都能按信号行动，分散最优值才恢复为 1。

团队最优因此既是收益标准，也是信息条件下的可实现性问题。找到一次成功协调或参数空间中的局部最优，都不能替代全局最大化；一般和问题更不能未经授权直接改成团队目标。

7.2.2 零和对抗下的极小极大标准

窄通道也可抽出一个“猜对方选哪侧”的对抗子任务。第一人选左右，第二人猜左右；选择相同给第一人 1，不同给第一人 -1。令行对应第一人的选择、列对应第二人的选择，其收益矩阵为

$$\boldsymbol{A} = \begin{pmatrix} 1 & -1 \\ -1 & 1 \end{pmatrix}. \tag{7.2}$$

第一人固定左或固定右，都有一个使其收益为 -1 的对手纯动作；均匀随机时，对任意列的期望均为 0。随机化并非让轨迹更确定，而是让对手无法利用确定的行动偏好。

一般地，令 $\boldsymbol{A} \in \mathbb{R}^{p\times q}$，混合策略 $\boldsymbol{x} \in \Delta_p$、$\boldsymbol{y} \in \Delta_q$ 是纯动作上的概率分布，第一人的期望收益为 $\boldsymbol{x}^{\top}\boldsymbol{A}\boldsymbol{y}$。第一人最大化它，第二人最小化它。给定对方策略时的最优选择称为**最佳响应**（best response）；**鞍点**要求双方分别固定对方后都不能改进自己的目标。

定理 7.3　有限零和博弈的极小极大等式　有限动作集合、允许全部混合策略且收益双线性时，

$$\max_{\boldsymbol{x}\in\Delta_p}\min_{\boldsymbol{y}\in\Delta_q}\boldsymbol{x}^{\top}\boldsymbol{A}\boldsymbol{y} = \min_{\boldsymbol{y}\in\Delta_q}\max_{\boldsymbol{x}\in\Delta_p}\boldsymbol{x}^{\top}\boldsymbol{A}\boldsymbol{y}.$$

双方均存在达到共同价值的策略，且构成鞍点。

证明　对固定 $\boldsymbol{x}$，线性函数在单纯形上的最小值是某一列收益的最小值，故左侧等于线性规划

$$\max_{\boldsymbol{x},v} v, \qquad \boldsymbol{A}^{\top}\boldsymbol{x} \geq v\mathbf{1}, \quad \mathbf{1}^{\top}\boldsymbol{x} = 1, \quad \boldsymbol{x} \geq 0.$$

对不等式引入 $\boldsymbol{y} \geq 0$，对归一化等式引入自由变量 w，拉格朗日式为

$$v + \boldsymbol{y}^{\top}(\boldsymbol{A}^{\top}\boldsymbol{x} - v\mathbf{1}) + w(1 - \mathbf{1}^{\top}\boldsymbol{x}) = w + v(1 - \mathbf{1}^{\top}\boldsymbol{y}) + \boldsymbol{x}^{\top}(\boldsymbol{A}\boldsymbol{y} - w\mathbf{1}).$$

对自由 v 及非负 $\boldsymbol{x}$ 取上确界有限，当且仅当 $\mathbf{1}^{\top}\boldsymbol{y} = 1$ 且 $\boldsymbol{A}\boldsymbol{y} \leq w\mathbf{1}$。因此对偶为

$$\min_{\boldsymbol{y},w} w, \qquad \boldsymbol{A}\boldsymbol{y} \leq w\mathbf{1}, \quad \mathbf{1}^{\top}\boldsymbol{y} = 1, \quad \boldsymbol{y} \geq 0,$$

恰好是右侧。任意概率向量配以 $v = \min_{r,c} A_{r,c}$ 使原问题可行，任意概率向量配以 $w = \max_{r,c} A_{r,c}$ 使对偶可行。所有期望收益落在这两个有限数之间，两问题均有界。由有限维线性规划强对偶及最优解存在性，最优目标相等，记为 v^{*}。最优 $\boldsymbol{x}^{*}, \boldsymbol{y}^{*}$ 满足对任意 $\boldsymbol{y}, \boldsymbol{x}$，$\boldsymbol{x}^{*\top}\boldsymbol{A}\boldsymbol{y} \geq v^{*}$ 且 $\boldsymbol{x}^{\top}\boldsymbol{A}\boldsymbol{y}^{*} \leq v^{*}$；取彼此得到等号，正是鞍点。 ■

这一证明承接第2章的线性规划工具。紧凸的混合策略集合是关键；若策略被限制为非凸神经网络参数类，不能直接搬用等式。

回到完全可观测、两人零和的折扣随机博弈，令 $Q(s,\cdot,\cdot)$ 为状态 s 的阶段收益矩阵，记其极小极大值为 $\operatorname{val} Q(s)$，则

$$(\mathcal{T}Q)(s,\boldsymbol{a}) = R_1(s,\boldsymbol{a}) + \gamma \sum_{s'} P(s' \mid s,\boldsymbol{a}) \operatorname{val} Q(s'). \tag{7.3}$$

Minimax-Q 用 $r_{1,t} + \gamma \operatorname{val} Q(s_{t+1})$ 作样本目标，再以步长 α_t 更新当前表项。例如奖励 1、后继博弈价值 0、旧值 0.4、步长 0.5 时，新值为 0.7。每次求后继价值需要解阶段线性规划，而非只取一个动作最大值。原始 Minimax-Q 由此将单智能体备份扩展到对抗决策[7]。

目标式正确不等于任何采样实现都收敛。表格收敛还要求有界奖励、各状态联合动作充分访问、适当随机逼近步长及正确求解阶段价值；深度逼近、局部观测或共同变化的数据覆盖均需另行分析。

[7] M. L. Littman, *Markov Games as a Framework for Multi-Agent Reinforcement Learning* In Machine Learning Proceedings 1994, 1994, pp. 157–163

7.2.3 一般和博弈下的均衡与社会目标

若两人都希望通行，稳定性也不意味着敌对。令两人选择左右让行，选择相同约定时收益为 $(2,2)$，不同为 $(0,0)$。两个对角纯策略都稳定：在对方不变时，自己换边会把 2 变成 0。但在另一个教学矩阵中，双方合作为 $(3,3)$，单方抢行为 $(5,0)$ 或 $(0,5)$，双方抢行为 $(1,1)$。逐行逐列比较可知抢行严格优于合作，稳定结果却比 $(3,3)$ 的总收益低。

定义 7.4　有限阶段博弈的偏离标准　令 $u_i(\boldsymbol{a})$ 为固定有限阶段博弈的收益。Nash 均衡是独立混合策略 $\boldsymbol{\pi}$，满足对任意 i 和替代混合策略 π_i'，$\mathbb{E}_{\boldsymbol{\pi}} u_i \geq \mathbb{E}_{\pi_i', \boldsymbol{\pi}_{-i}} u_i$。对联合建议分布 $q(\boldsymbol{a})$，**粗相关均衡**（coarse correlated equilibrium, CCE）要求

$$\mathbb{E}_q[u_i(\boldsymbol{a}) - u_i(b_i, \boldsymbol{a}_{-i})] \geq 0 \quad \text{对所有} i, b_i.$$

相关均衡（correlated equilibrium, CE）要求

$$\sum_{\boldsymbol{a}_{-i}} q(a_i, \boldsymbol{a}_{-i})[u_i(a_i, \boldsymbol{a}_{-i}) - u_i(b_i, \boldsymbol{a}_{-i})] \geq 0 \quad \text{对所有} i, a_i, b_i.$$

CCE 比较“收到建议前就改用一个固定动作”，CE 允许“看见自己收到的建议后再决定如何替换”。CE 约束更强；这里写的是未条件化形式，罕见建议也按其发生概率计权。Nash 使用边缘策略乘积，CE 和 CCE 允许相关建议。协调博弈中，以各 $1/2$ 概率建议双方都左或都右是 CE；若把它换成两个边缘的独立乘积，便有一半概率失配。联合分布携带的协调信息不能随意丢掉。

有限参与者、有限纯策略的博弈至少存在一个混合 Nash 均衡。证明的关键桥梁是：各人混合策略单纯形非空、紧且凸；收益对自身混合策略线

性，故最佳响应集合非空且凸；收益连续使最佳响应对应具有闭图。对有限维紧集合，这些条件允许应用 Kakutani 不动点定理，得到每个人都是其他人最佳响应的不动点。Nash 的存在性工作支持的是这一步，不是高效计算或任意学习过程的收敛[8]。

[8] J. F. Nash Jr., *Equilibrium Points in n-Person Games* In Proceedings of the National Academy of Sciences, 1950, vol. 36, no. 1, pp. 48–49

表7.4汇总了要报告的对象。若问题跨越多步，“替代动作”应改成从全部相关历史到动作的完整策略，或者明确仅检验某种受限状态条件偏离。某个访问状态上的阶段 CE，不能自动保证整条轨迹无人能通过改变后续行为获利。

标准	偏离对象与信号	保证与未规定部分
Nash	固定对手后换自身策略；独立随机化	无单方收益改进；未最大化福利
CE	根据自己收到的建议换动作	无建议条件偏离；需合法相关信号
CCE	看建议前改为固定动作	无事前固定偏离；不排除条件偏离
福利目标	按给定聚合函数选联合结果	可比较社会收益；不自动保证稳定或公平

表 7.4 均衡与社会目标的区别。表中动作约束属于固定阶段博弈；序贯问题必须另行声明完整策略或受限偏离类。

Nash-Q 在每个后继状态的多张价值矩阵中选取一个阶段 Nash 均衡 $\boldsymbol{\sigma}^*(s')$，再令

$$y_i = r_i + \gamma \sum_{\boldsymbol{a}'} \boldsymbol{\sigma}^*(\boldsymbol{a}' \mid s') Q_i(s', \boldsymbol{a}').$$

例如后继协调矩阵选“都左”时，各人后继值为 2；若即时奖励为 0 且 $\gamma = 0.9$，目标为 1.8。问题在于多个均衡可能给不同收益，选取规则的不连续还会改变更新动态。Nash-Q 原文的收敛分析有特殊的阶段均衡条件，不能由存在性推出一般深度 Nash-Q 必然收敛[9]。

[9] J. Hu, M. P. Wellman, *Nash Q-Learning for General-Sum Stochastic Games* In Journal of Machine Learning Research, 2003, vol. 4, pp. 1039–1069

7.3 多智能体的联合经验获取

一个团队每人都探索过，不等于团队探索过每种配合方式。联合经验获取要从待估量出发，记录谁与谁在什么信息下采取了什么行为，再决定这些数据支持哪些结论。固定日志使用者不能重做采集，只能从已有生成条件开始检查。

7.3.1 联合经验需求与采集方案的确定

评价现有让行团队，只需在部署伙伴分布和当前策略下估计回报；改进自己，需要比较尚未采用的自身行为；检验单方偏离，还需让替代策略访

问它可能到达的后续状态。相同轨迹数量对这三个任务的支持程度不同。表7.5把估计需求转成可操作的采集选择。

待估量	所需联合行为与参与者范围	可控因素与预算
当前团队回报	当前联合策略及部署伙伴分布	固定策略，重复独立回合，预算按回合计
自身改进价值	固定或条件化伙伴下的候选自身动作	探索强度与起点；按联合环境步计
单方偏离收益	原对手固定，完整候选响应的轨迹	响应训练、验证分开；计对手查询
新伙伴协调	留出伙伴及允许探测的历史	伙伴抽样、角色与通信；计适应步数

表 7.5 经验需求决定采集方案，而不是用轨迹总数替代覆盖条件。预算还须报告每类参与者的分配。

具体方案应规定伙伴或群体分布 $q(k)$、各行为策略 $\mu_i^{(k)}$、角色分配、行动时序及探索噪声。身份是“谁”，版本是“采用哪一套参数”，学习状态是“本回合是否还会更新”，三者应分别记录。选择均匀抽样只意味着预期支持较广，不能证明采到的数据已覆盖罕见联合事件。固定日志缺少来源时，只能列明确知条件，不能根据轨迹看起来像均匀探索就补上行为概率。

OpenAI Five 提供了按版本组织采样的实际例子：其报告中的训练对局有 80% 面向最新参数、20% 面向历史版本，历史版本的抽样分布还随对局表现改变。因此，“保留历史对手”仍不足以恢复数据来源，还需知道当时如何抽样[10]。

[10] OpenAI, C. Berner, G. Brockman, B. Chan, V. Cheung, P. Dębiak, C. Dennison, D. Farhi, Q. Fischer, S. Hashme, C. Hesse, R. Józefowicz, S. Gray, C. Olsson, J. Pachocki, M. Petrov, H. P. d. O. Pinto, J. Raiman, T. Salimans, J. Schlatter, J. Schneider, S. Sidor, I. Sutskever, J. Tang, F. Wolski, S. Zhang, *Dota 2 with Large Scale Deep Reinforcement Learning*, 2019, arXiv: 1912.06680, URL: https://arxiv.org/abs/1912.06680v1 (visited on 10/04/2026)

7.3.2 联合轨迹采集与生成条件记录

一条联合转移至少记录 (s_t或$\boldsymbol{o}_t, \boldsymbol{a}_t, \boldsymbol{r}_t, \boldsymbol{o}_{t+1}$,终止)，并关联动作前后的消息、各人身份、策略版本和合法动作集合。为了离策略校正，还需记录伙伴抽样概率、给定实际可用历史的动作概率，以及公共信号或相关采样机制。仅保存版本号不足以重建概率：还应保留参数检查点、探索噪声规则和动作屏蔽逻辑。

设通道只有双方同时选择“按按钮”才打开，每人独立以 0.1 概率探索该动作。一次成功触发的概率为 $0.1^2 = 0.01$，100 次独立尝试仍一次也未触发的概率为 $0.99^{100} \approx 0.366$。若合法公共信号以 0.1 概率指示双方同时按，边缘探索率仍为 0.1，联合触发率却升为 0.1。图7.5展示这一区别；相关性要由执行时真正共享的信息产生，不能由未授权的中央动作控制暗中实现。

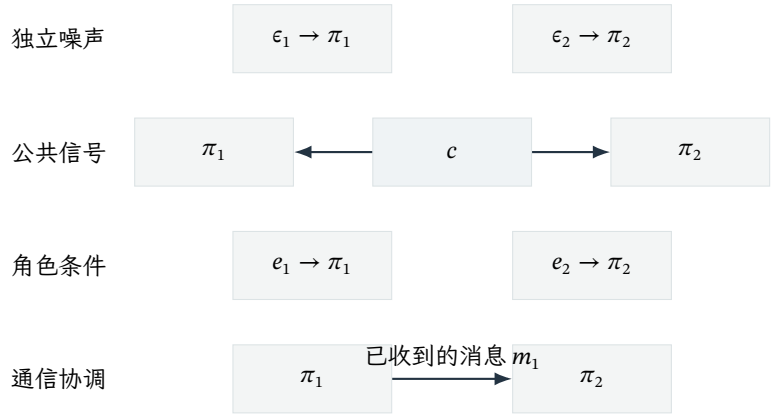


图 7.5　四种探索路径。独立噪声不产生共同事件保证；公共信号、角色条件与通信分别提供不同的协调依据。箭头标出执行者实际接收的信息。

上述公共信号例中 $\mathbb{P}(a_1 = \text{按}, a_2 = \text{按}) = 0.1$，而边缘乘积为 0.01。把后者写进行为日志会使重要性权重错十倍。通信依赖或同一随机数驱动的动作也有同样问题；应记录真实联合概率，或记录足以使条件独立成立的信号后再分解。

7.3.3 经验分布变化与目标覆盖检验

式(7.1)可用于比较版本。若版本 k 的对手等待概率为 $q^{(k)}$，自身前进的诱导奖励为 $-4 + 3q^{(k)}$。版本差 Δq 对应奖励差 $3\Delta q$，并可能通过通过概率改

变后续状态占用。但“版本变了”只表明分布可能变化；实际漂移的证据应来自分层统计、预测残差或已知策略概率，而不是仅凭版本编号宣布环境变坏。

最容易漏掉的是联合支持。设日志生成机制仅以各 $1/2$ 概率选择 $(0,0)$ 和 $(1,1)$，两个非对角动作的概率均为 0。每人的两个动作都有支持，但 $(0,1)$ 和 $(1,0)$ 没有联合支持。构造两个奖励模型，使它们在对角线上均给 0、在非对角线上分别给 10 与 -10，便得到相同日志分布却相反的候选偏离收益。没有额外结构假设时，边缘覆盖不能识别这些联合效果。

表7.6把覆盖对象细分。样本零频率不等于总体零概率，有限数据可给出频率及其不确定性，却无法仅凭“尚未见过”断言绝对不可能；同理，未检出漂移也不能证明机制恒定。

估计对象	所需支持	典型缺失
目标联合价值	目标到达状态及联合动作，目标伙伴	某种配合从未采到
最佳响应	固定对手下候选完整策略的状态与动作	只记录原策略的到达状态
个体反事实优势	固定其他动作后的自身候选动作	对角数据不能估非对角值
消息条件价值	对应消息历史、角色、策略类型	未记消息使条件分布不可恢复

表 7.6　不同待估量需要不同支持。集中状态可以增加条件信息，但不能补出未发生的联合行为。

7.3.4 覆盖充分时的可用经验构造

确认目标支持被行为支持覆盖后，仍需处理“有数据但来源不匹配”。最近窗口减少版本跨度，却丢弃较旧数据；按参与者分层可以控制伙伴组成；对手条件价值把类型或版本作为估计输入；重要性校正则用概率比改变期望的测度。它们调整的对象不同，可以组合，不能把任何一种叫作自动消除非平稳性。

令 k 表示一次回合抽取的策略群体身份，τ 为长度 H 的完整记录轨迹，q_μ, q_π 为行为和目标伙伴分布。在初始分布、转移与反馈核及终止协议相同，且目标联合轨迹分布对行为分布绝对连续时，

$$w(\tau,k)=\frac{p_\pi(\tau,k)}{p_\mu(\tau,k)}=\frac{q_\pi(k)}{q_\mu(k)}\prod_{t=0}^{H-1}\frac{\boldsymbol{\pi}(\boldsymbol{a}_t\mid \boldsymbol{h}_t,k)}{\boldsymbol{\mu}(\boldsymbol{a}_t\mid \boldsymbol{h}_t,k)}. \tag{7.4}$$

环境转移和观测项相消，策略生成的消息若未含在动作内，还要保留消息概率比。只有给定记录历史及公共信号后各人条件独立时，每个联合动作比才等于 $\prod_i \pi_i(a_{i,t}\mid h_{i,t},k)/\mu_i(a_{i,t}\mid h_{i,t},k)$。若公共信号的分布也改变，还

需它的概率比。对完整轨迹函数 f 有 $\mathbb{E}_\pi f = \mathbb{E}_\mu[wf]$；逐决策估计则使用截至相应奖励时刻的前缀比。

这给出了可执行的构造：按来源分层取样，恢复真实条件概率，计算权重，再用加权回报或损失估计目标。其成本是每条长度 H 轨迹至少计算 mH 个个体策略概率，以及伙伴和信号概率。若每个个体概率比均为 2，十人同一步的乘积即为 1024；长轨迹会进一步放大权重波动。截断 w 为 $\min(w, c)$ 可控制极端样本影响，却将期望改为 $\mathbb{E}_\mu[\min(w, c)f]$，产生需要报告的偏差。行为概率为零的事件不能靠设“无限大权重”恢复。

策略指纹把训练轮次、探索率等生成条件送入价值网络，帮助区分旧数据；它不是概率比，不能据此声称无偏。经验回放中的多智能体重要性校正与指纹方法已有直接比较，但原结果依赖其具体任务及实现条件[11]。

[11] J. Foerster, N. Nardelli, G. Farquhar, T. Afouras, P. H. S. Torr, P. Kohli, S. Whiteson, *Stabilising Experience Replay for Deep Multi-Agent Reinforcement Learning* In Proceedings of the 34th International Conference on Machine Learning, 2017, pp. 1146–1155

7.3.5 覆盖不足时的经验补充与学习边界

发现缺口后，动作取决于访问权限。未见参与者可通过调整伙伴抽样补充；未见联合动作可用合法公共信号或通信协调探索；未达状态需要改变到达策略，而不只是入口增加噪声；未记录信息则要修改后续日志字段，已经丢失的历史通常不能追补。图7.6把这一判断接回经验闭环。

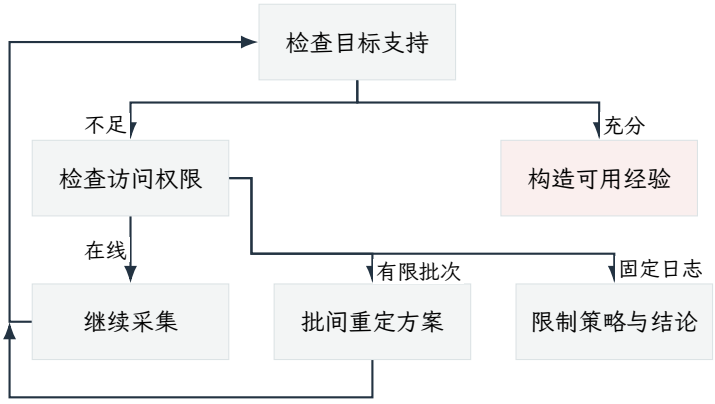


图 7.6　覆盖检验后的权限分支。在线访问可继续采集；有限批次只能在批间调整方案；固定日志必须限制目标或引入可检验假设，不能沿采集回路继续交互。

有限批次的一个明确协议是总共 B 批，每批 N_b 个联合环境步。第 b 批内冻结行为策略、伙伴抽样及探索规则，批结束后才用反馈选择第 $b+1$ 批方案。若对手有内部在线适应，则须把它声明为策略的一部分并记录相应历史，不能再当作状态条件的固定对手。在固定日志条件下，只能限制策略落在有支持区域、增加可检验结构假设，或采用第4章的悲观评价。增大网络并不能使未见联合动作的效果变得可识别。

7.4 不同参与者依赖下的行为后果估计

现在固定可用经验，考虑从中估计什么。联合价值保留所有人的当前动作，个体反事实固定别人而比较自己，局部组合约束价值怎样分解，对方模型保留策略类型，相互响应则保留别人如何随自己变化。这五个视角可以重叠：一个集中评论家既可以条件于伙伴类型，又可以输出 COMA 的候选动作价值；一个群体学习器也可以用单调分解计算近似响应。

7.4.1 基于联合行为的后果估计

固定联合策略 $\boldsymbol{\pi}$ 后，价值评价的对象不再含糊。令 x_t 为训练时足以预测后继过程的集中信息：完全可观测、无记忆策略时可取 s_t；使用历史策略时可取 $(s_t, \boldsymbol{h}_t)$。记其转移核为 P_x，奖励条件均值为 $R_i(x, \boldsymbol{a})$，并令 $G_{i,t} = \sum_{k\ge 0} \gamma^k r_{i,t+k}$，定义

$$Q_i^{\boldsymbol{\pi}}(x, \boldsymbol{a}) = \mathbb{E}[G_{i,t} \mid x_t = x, \boldsymbol{a}_t = \boldsymbol{a}], \tag{7.5}$$

$$V_i^{\boldsymbol{\pi}}(x) = \sum_{\boldsymbol{a}} \boldsymbol{\pi}(\boldsymbol{a} \mid x) Q_i^{\boldsymbol{\pi}}(x, \boldsymbol{a}). \tag{7.6}$$

这里 $\boldsymbol{\pi}(\boldsymbol{a} \mid x)$ 仍由各合法局部策略产生，不是允许行动者读取整个 x。Q_i 回答“本次联合动作已固定，之后照旧执行会怎样”，V_i 则连本次动作也按现有策略平均。即使 $\boldsymbol{\pi}$ 不选择某个合法联合动作，其 Q_i 仍按从 x 强制执行该动作、随后遵循 $\boldsymbol{\pi}$ 的过程定义，而不靠零概率事件上的条件期望确定。

把即时回报与下一步分开，得到固定策略的 Bellman 评价

$$Q_i^{\boldsymbol{\pi}}(x, \boldsymbol{a}) = R_i(x, \boldsymbol{a}) + \gamma \sum_{x'} P_x(x' \mid x, \boldsymbol{a}) \sum_{\boldsymbol{a}'} \boldsymbol{\pi}(\boldsymbol{a}' \mid x') Q_i^{\boldsymbol{\pi}}(x', \boldsymbol{a}'). \tag{7.7}$$

离散求和在连续空间中改为积分。训练时，一条联合转移给出目标 $y_i = r_i + \gamma(1 - z) V_{i,\text{目标}}(x')$，$z$ 表示真实终止；最小化 $(Q_{i,\boldsymbol{\phi}}(x, \boldsymbol{a}) - y_i)^2$ 即可得到一个 TD 更新。截断采样而未终止时不能把 z 误设为 1。

Minimax-Q 把内层策略平均换成零和阶段价值，Nash-Q 换成选定的阶段均衡收益；这是更换行为标准后的控制备份，不是同一个固定策略评价式的不同记号。表7.7还说明，集中训练本身并未规定评论家必须输入联合动作。

MADDPG 把确定性行动者与集中动作价值结合，可用于合作和竞争收益；MAPPO 研究则在合作任务中考察集中状态价值与 PPO 的配合，给出的是相应实现条件下的经验结果[12,13]。

两种方法都要从联合轨迹估计目标，成本包括集中输入传输、价值网络前后向和数据存储。输入更充分可减少把他人动作误当噪声的程度，却

[12] R. Lowe, Y. Wu, A. Tamar, J. Harb, P. Abbeel, I. Mordatch, *Multi-Agent Actor-Critic for Mixed Cooperative-Competitive Environments* In Advances in Neural Information Processing Systems, 2017

[13] C. Yu, A. Velu, E. Vinitsky, J. Gao, Y. Wang, A. Bayen, Y. Wu, *The Surprising Effectiveness of PPO in Cooperative Multi-Agent Games* In Advances in Neural Information Processing Systems, 2022, pp. 24611–24624

方法	训练输入与评价对象	策略更新与执行
MADDPG	集中信息 x 及 $\boldsymbol{a}$；各自 $Q_i(x,\boldsymbol{a})$	对自身动作求价值梯度；执行仅用局部输入的确定性行动者
MAPPO	集中状态或联合观测，可补个体信息；$V_i(x)$ 或团队 $V(x)$	用回报与 V 构造优势；执行仅用局部输入的随机行动者

表 7.7　两种集中评论家的接口。输入联合观测是否足以成为 Markov 状态，需要另行论证；集中状态价值不以当前联合动作为必需输入。

不会冻结其他策略，也不会消除函数逼近误差。若 x 只包含当前观测而遗漏对方记忆，式(7.7)中的 Markov 解释仍可能不成立；执行权限也仍受第7.1.4节约束。

7.4.2 基于个体行为反事实的后果估计

团队得到 2 分时，不能只给每人同样的强化信号便认为贡献已经分清。本小节的信用分配数值例及下一小节的单调表示反例，把入口截成一次联合动作后立即结束的独立矩阵任务，因此动作价值等于即时奖励。沿用合作奖励表：(F,F) 得 -2，(W,W) 得 -1，恰好一人前进得 2。观察到 (F,W) 后，固定 2 的等待，1 从 F 改成 W 会把奖励从 2 降到 -1；固定 1 的前进，2 从 W 改成 F 会把奖励从 2 降到 -2。一次成功包含两种不同作用：1 启动通过，2 避免冲突。

若有一个明确定义的参照动作 c_i，**差分奖励**（difference reward）可写成 $D_i = R(x,\boldsymbol{a}) - R(x,(c_i,\boldsymbol{a}_{-i}))$。在上述已知一步奖励表中，令 $c_1 = W$，便有 $D_1 = 3$。实际系统往往没有第二次实测结果，替代动作也可能改变后继状态；这时必须说明差分来自模型、额外试验还是价值估计，不能把它当作日志中天然存在的字段。

长期个体优势比较的是动作价值，而不只是即时奖励。COMA 保持 $\boldsymbol{a}_{-i}$ 不变，对 i 的候选动作按当前策略加权：

$$b_i(x,\boldsymbol{a}_{-i}) = \sum_{\tilde{a}_i} \pi_i(\tilde{a}_i \mid h_i) Q^{\boldsymbol{\pi}}(x,(\tilde{a}_i,\boldsymbol{a}_{-i})), \tag{7.8}$$

$$A_i^{\mathrm{COMA}}(x,\boldsymbol{a}) = Q^{\boldsymbol{\pi}}(x,\boldsymbol{a}) - b_i(x,\boldsymbol{a}_{-i}). \tag{7.9}$$

在上述单步任务中，若 1 以 $1/4$ 概率前进、$3/4$ 概率等待，在 2 等待的条件下，基线为 $\frac{1}{4}(2)+\frac{3}{4}(-1) = -1/4$，实际前进的优势为 $9/4$。这与参照固定等待得到的差分 3 不同，因为比较对象不同。

这种基线为什么可以依赖别人的实际动作？把获准使用的公共信号纳入各自 h_i，并假设给定充分信息 x 及其他动作 $\boldsymbol{a}_{-i}$ 后，i 的条件动作分布仍为 $\pi_i(\cdot \mid h_i)$。在策略可微、支持固定且相关乘积可积的条件下，基线

$b_i(x, \boldsymbol{a}_{-i})$ 不依赖本次抽到的 a_i；更新时将其视为常数，不通过它反向传播。于是

$$\begin{aligned}&\mathbb{E}_{a_i|x,\boldsymbol{a}_{-i}}[\nabla_{\theta_i} \log \pi_i(a_i \mid h_i) b_i(x, \boldsymbol{a}_{-i})] \\ &\quad = b_i(x, \boldsymbol{a}_{-i}) \sum_{a_i} \nabla_{\theta_i} \pi_i(a_i \mid h_i) = 0.\end{aligned} \tag{7.10}$$

再对 $(x, \boldsymbol{a}_{-i})$ 取期望即得到零均值结论。这正是定理3.12的多智能体条件版。若两人共享未记录的随机信号，给定 $\boldsymbol{a}_{-i}$ 后 i 的分布可能已不等于 π_i，上述替换便不合法。应在真实联合策略中显式处理相关信号，并重新推导得分与基线；仅把得分换成另一个条件分布的对数梯度，不能保证仍在估计原目标梯度。

COMA 的评论家可一次输出所有自身候选动作的价值，避免对每个候选重新运行完整网络；但输出维度仍随 $|\mathcal{A}_i|$ 增长，连续动作还需积分近似。目标与采样仍来自联合轨迹，候选价值是模型估计，不是未执行动作的新事实。原方法将这一基线用于集中评论家和分散行动者[14]。

零均值只表明减去基线不改变精确策略梯度的期望，不保证方差必然降低；差的评论家还会使优势估计失真。这里的“反事实”是固定其他当前动作后的候选价值比较，不等于在因果结构模型中识别唯一真实的个体因果贡献。

[14] J. Foerster, G. Farquhar, T. Afouras, N. Nardelli, S. Whiteson, *Counterfactual Multi-Agent Policy Gradients* In Proceedings of the AAAI Conference on Artificial Intelligence, 2018

7.4.3 基于局部行为组合的后果估计

集中价值能给联合动作打分，却未必能让分散执行者自己选出这个动作。假设每人只计算局部效用 $q_i(h_i, a_i)$，执行 $a_i^* \in \arg\max_{a_i} q_i(h_i, a_i)$。这里 q_i 是为组合团队行为而学习的内部量，不必等于参与者 i 的环境回报。所需的**个体与整体最大化一致性**（individual-global-max, IGM）至少要求这些局部贪心动作能组合成联合贪心动作。

图7.7比较两种组合结构。VDN 直接令 $Q_{\text{tot}} = \sum_i q_i$；QMIX 让训练状态决定混合器参数，并用非负权重及单调激活限制 $\partial Q_{\text{tot}}/\partial q_i \geq 0$。部署时只保留局部效用的贪心选择，不需要取得状态。两者分别约束可表示联合价值的加和性与单调性[15,16]。

这些结构为何能让各人独立选动作？下面的充分条件把局部选择与联合最优连接起来。

定理 7.5　单调组合的局部贪心充分性　固定训练信息 x 和所有局部历史，动作集合为笛卡尔积，且各局部最大值存在。若

$$Q_{\text{tot}}(x, \boldsymbol{a}) = f_x(q_1(h_1, a_1), \dots, q_m(h_m, a_m))$$

对每个局部效用逐坐标非减，则

$$\prod_i \arg\max_{a_i} q_i(h_i, a_i) \subseteq \arg\max_{\boldsymbol{a}} Q_{\text{tot}}(x, \boldsymbol{a}).$$

证明　任选一组局部最大化动作 $\boldsymbol{a}^*$ 和任意联合动作 $\boldsymbol{a}$。将 $\boldsymbol{a}$ 的第一分量换成 a_1^* 时，第一局部效用不会下降，其余效用不变；f_x 的第一坐标非减，故联合价值不下降。接着把第二分量换成 a_2^*，同理价值不下降。逐一替换完 m 个分量后得到 $Q_{\text{tot}}(x, \boldsymbol{a}) \leq Q_{\text{tot}}(x, \boldsymbol{a}^*)$。任意 $\boldsymbol{a}$ 都满足此式，故 $\boldsymbol{a}^*$ 为联合最大化动作。$\boldsymbol{a}^*$ 可任取自局部最大集合的笛卡尔积，包含关系成立。 ■

不能把这里的包含号无条件改为等号。例如 f_x 为常数，所有联合动作都最优，而 q_1 可以只有一个最大化动作。平台区间和并列效用也会产生同样差别。若存在耦合动作限制，使各人合法动作的乘积包含非法联合动作，证明中的逐分量替换也须重新检查。

单调性也限制了表达能力。沿用前一小节的单步终止约定，入口奖励表的两列分别要求 $Q(F,F) < Q(W,F)$ 和 $Q(F,W) > Q(W,W)$。若 $q_1(F) > q_1(W)$，第一列违反非减性；若小于，第二列违反；若相等，两列都无法得到严格差别。因此同一历史下的标量局部效用与单调混合器不能精确表示这张表。不过固定约定“1 前进、2 等待”仍然可执行且最优。最优动作可执行、整张价值表可表示、训练能找到该动作，是三个不同问题。

[15] P. Sunehag, G. Lever, A. Gruslys, W. M. Czarnecki, V. Zambaldi, M. Jaderberg, M. Lanctot, N. Sonnerat, J. Z. Leibo, K. Tuyls, T. Graepel, *Value-Decomposition Networks for Cooperative Multi-Agent Learning Based on Team Reward* In Proceedings of the 17th International Conference on Autonomous Agents and Multiagent Systems, 2018, pp. 2085–2087

[16] T. Rashid, M. Samvelyan, C. Schroeder, G. Farquhar, J. Foerster, S. Whiteson, *QMIX: Monotonic Value Function Factorisation for Deep Multi-Agent Reinforcement Learning* In Proceedings of the 35th International Conference on Machine Learning, 2018, pp. 4295–4304

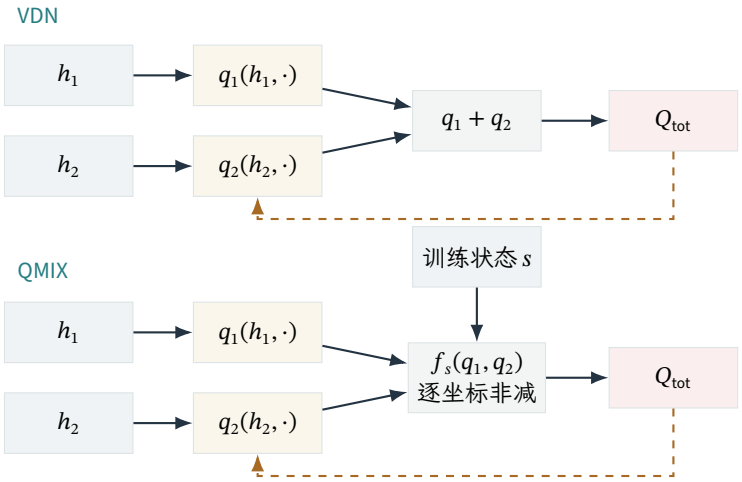


图 7.7 VDN 与 QMIX 的价值组合。实线为计算输入，虚线为联合 TD 损失返回局部效用的训练梯度；状态只进入 QMIX 训练混合器。执行时读取每个 q_i 的局部最大化动作。

表7.8中的方法放松或改写了表示约束，而不是把训练信息权限自动放宽。QTRAN 用保持最优动作的变换及一致性约束；QPLEX 用优势分解刻画更一般的 IGM 结构。它们的表示论证须与约束是否实际满足、函数逼近及优化误差分开[17,18]。

结构	保留的限制或分解	代价与边界
VDN	联合价值为局部效用之和	组合便宜；不能表达一般相互作用
QMIX	状态条件的逐坐标非减混合	增加混合器；局部排序不能随他人动作反转
QTRAN	联合价值与易分解变换在贪心处相等、其他动作满足不等式	需拟合联合值并施加约束；近似惩罚不保证精确满足
QPLEX	局部优势 $q_i - \max q_i \le 0$ 以正权组合，另建联合基准值	优势与权重结构增加表达力；表示充分性不等于优化收敛

表 7.8 改变局部组合约束的几种方式。它们可与伙伴条件化、回放管理及群体训练组合。

这些方法都可从联合转移构造团队 TD 目标并反传到局部网络；区别是目标最大化如何实现、哪些价值模式能被结构容纳。若每人有 A 个动作，直接枚举联合动作要处理 A^m 个组合，局部贪心只需比较 mA 个效用再调用混合器。节省的是这一计算环节，并不证明同等样本就足以学好所有效用。

[17] K. Son, D. Kim, W. J. Kang, D. E. Hostallero, Y. Yi, *QTRAN: Learning to Factorize with Transformation for Cooperative Multi-Agent Reinforcement Learning* In Proceedings of the 36th International Conference on Machine Learning, 2019, pp. 5887–5896

[18] J. Wang, Z. Ren, T. Liu, Y. Yu, C. Zhang, *QPLEX: Duplex Dueling Multi-Agent Q-Learning* In International Conference on Learning Representations, 2021

7.4.4　基于其他参与者策略的行为后果估计

同一前进动作面对主动让行者和坚持前进者，后果并不相同。设伙伴类型 z 在整个教学回合内固定，取“让行型” G 或“坚持型” S，等待概率分别为 0.8、0.2；给定类型，各次入口动作独立且可观察，先验各为 $1/2$。观察到 W, W, F 后，两类似然为 $0.8^2 \cdot 0.2 = 0.128$ 和 $0.2^2 \cdot 0.8 = 0.032$，故后验 $\mathbb{P}(G \mid h) = 0.8$。预测下一次等待概率变为 $0.8(0.8) + 0.2(0.2) = 0.68$，自己的前进即时期望收益为 $-4 + 3(0.68) = -1.96$。

一般地，伙伴信念 $b_t(z) = \mathbb{P}(z \mid h_{i,t})$ 是给定获准历史后对行为类型的分布。自己的动作 $a_{i,t}$ 会影响随后可见证据 e_{t+1}，因此似然应写成 $\ell(e_{t+1} \mid h_{i,t}, a_{i,t}, z)$。若自身动作仅由已记录历史和独立随机数产生，则其概率在候选类型间相同，归一化时可以消去：

$$b_{t+1}(z) = \frac{\ell(e_{t+1} \mid h_{i,t}, a_{i,t}, z) b_t(z)}{\sum_{\tilde{z}} \ell(e_{t+1} \mid h_{i,t}, a_{i,t}, \tilde{z}) b_t(\tilde{z})}.$$

分母须大于 0。若动作选择还利用了未记录的类型线索，就不能直接消去动作概率。未直接看见伙伴动作时，似然须对隐藏动作、状态或消息求和，不能把其真实动作当作可见训练标签使用于部署辨识。若类型外生转移，还应先通过类型转移核预测，再用新证据校正。这与式(6.8)使用相同的贝叶斯步骤，推断对象改成了参与者行为。

候选动作的价值可以按类型取平均，但所有类型下必须评价同一套后续策略及信念更新规则。令 $Q_i(h_i, b, a_i, z)$ 表示在类型 z 下执行 a_i、随后按该共同规则行动的条件回报，则 $Q_i(h_i, b, a_i) = \sum_z b(z) Q_i(h_i, b, a_i, z)$。每一项都要对尚未观察到的伙伴动作和状态作相应条件平均，不能分别使用“已知真实类型”的最优策略。若后续还会辨识类型，价值状态及递推必须保留信念更新；冻结信念的近似会漏掉探测的信息价值。

策略表示不必是有限标签，也可用从历史预测下一动作分布的嵌入。训练目标可以是可见动作的负对数似然，再将表示送入条件评论家或策略；一次更新的成本包括历史编码、类型似然及候选动作评价。它不要求读取对方网络参数。身份、检查点版本与潜在类型仍要分开：同一身份可改变策略，不同身份也可表现相同。此处把未知对手视为固定或外生变化；自己更新所诱发的响应需要额外建模。

7.4.5　基于参与者相互响应的行为后果估计

更激进的通行者可能迫使伙伴让行，也可能促使伙伴采取更强硬的规则。若只拟合伙伴当前等待率，就遗漏了“我改变后，对方也改变”的途径。作为教学响应模型，令自身前进概率为 p，伙伴等待率为 $q(p) = 0.8 - 0.6p$，则碰撞率为 $p(1 - q(p)) = 0.2p + 0.6p^2$；冻结 $q = 0.8$ 时只会预测 $0.2p$。这不是对真实人类行为的假设，只用于展示漏项。

以两人问题为例，用 $\psi = \mathcal{R}(\theta_i)$ 表示对方在看到 i 的策略或交互后采用的参数，J_{-i} 为另一人的目标。固定对方相当于 $\mathcal{R}$ 为常数；一步预期响应可以规定 $\mathcal{R}(\theta_i) = \psi + \eta \nabla_{\psi} J_{-i}(\theta_i, \psi)$，其中对方知道自己的目标、当前策略以及用于估计该梯度的数据。再增加一层，必须进一步规定对方是否知道 i 将如何更新，以及它是否也在预测 i；递归深度不是免费增加的准确性。

若 J_i 和 $\mathcal{R}$ 在所考察邻域可微，链式法则给出

$$\nabla_{\theta_i} J_i(\theta_i, \mathcal{R}(\theta_i)) = \partial_{\theta_i} J_i + [D\mathcal{R}(\theta_i)]^{\top} \nabla_{\psi} J_i. \tag{7.11}$$

第一项固定对方参数，只计自身动作分布改变的效果；第二项通过对方响应传递。在上述碰撞例的当前点 p_0，直接项为 $1 - q(p_0) = 0.2 + 0.6p_0$，间接项为 $-p_0 q'(p_0) = 0.6p_0$，合计 $0.2 + 1.2p_0$。这与从一开始就固定 $q = 0.8$、只预测导数 0.2 的模型不同。一步学习响应通常需要对对方更新求导，涉及梯度的导数；若只观察交互，必须先拟合响应模型，再承担模型误差。LOLA 给出利用对方学习步骤来构造此类更新的具体方法[19]。

式(7.11)把 $\mathcal{R}$ 视为确定映射。若对方用随机采样数据更新，对固定数据求导只是条件导数；当采样分布也依赖 θ_i 时，完整期望梯度还须计入该分布的导数。这与第6.4.4节元学习目标中的采样分布项是同一类区别。

最佳响应可能多解或不连续，未知对手也未必按假定规则学习，此时不能照搬式(7.11)。层数增加会放大推理成本与错设风险。准确预测下一次响应、在可承诺且可观察的先后行动条件下求得 Stackelberg 式承诺解、以及同时行动时达到 Nash 均衡，分别需要不同的协议和验证标准。

[19] J. Foerster, R. Y. Chen, M. Al-Shedivat, S. Whiteson, P. Abbeel, I. Mordatch, *Learning with Opponent-Learning Awareness* In Proceedings of the 17th International Conference on Autonomous Agents and Multiagent Systems, 2018, pp. 122–130

7.5 多智能体的策略更新与学习动态

价值和优势只提供更新所需的量，还没有规定所有学习者如何一起变化。本节组合三个视角：更新计算规定怎样从批次产生参数变化，相互响应规定每人追随当前还是历史行为，群体组织规定本轮同谁训练。例如 PSRO 可以从策略库抽样对手，用策略梯度训练一个近似最佳响应，再把新策略加入库。它同时使用三个选择，而不是属于其中一个互斥家族。

7.5.1 由价值与梯度计算策略更新

先冻结本轮其他策略及目标评论家。对批次 $\mathcal{B}$ 中的每条联合转移计算后继目标，再拟合价值或构造优势，最后产生新动作规则或策略参数。表7.9把几种价值更新放在同一接口上。只有输入包含充分状态且诱导环境平稳等条件成立时，才能援引表格型单智能体 Q 学习的保证；共同更新、局部历史压缩和函数逼近都可能使这些前提失效。

一个批次可以小到只有一条教学样本。设通道中采到 $r = 2$、未终止，目标网络给后继联合值 1，$\gamma = 0.9$，则 $y = 2.9$。若当前 $Q = 1$，对 $\frac{1}{2}(Q - y)^2$

方法	价值输入	后继备份	动作与执行信息
独立 Q	h_i, a_i	自身 $\max Q_i$	局部贪心；他人行为被边缘化
Minimax-Q	$s, \boldsymbol{a}$	零和矩阵价值	按解出的混合策略抽样；需状态
Nash-Q	$s, \boldsymbol{a}$ 的各人收益	选定阶段均衡收益	按同一均衡选择约定；需状态
VDN	局部 h_i, a_i 再求和	局部最大值之和	每人局部贪心
QMIX	局部效用与训练状态	单调混合的局部最大值	每人局部贪心；执行无须状态

表 7.9 价值到动作的更新接口。各行还需相应的联合采样、终止处理和目标网络；阶段博弈求解并不自动满足分散信息约束。

作步长 0.1 的表格梯度下降，得到 $Q' = 1.19$。VDN 中若当前两个效用为 0.4 和 0.6，各自都收到残差 -1.9，一次同步梯度步后变为 0.59 和 0.79，合计 1.38。它不等于直接更新联合表得到的 1.19，因为参数化改变了有效步长。QMIX 还要乘混合器对各效用的导数；Minimax-Q 和 Nash-Q 则把计算成本放在后继阶段求解器上。

随机策略可以直接用收益梯度更新。令 $\boldsymbol{\pi}_\theta = \prod_i \pi_{\theta_i}(a_i \mid h_i)$，各参数暂不共享，其他参数与环境机制固定；策略可微且支持固定，并沿用式(3.27)中交换求导与折扣求和所需的可积支配条件。对轨迹概率取对数后，只有 i 的动作项依赖 θ_i。将每个奖励之前的得分项合并为从该动作开始的回报，得到

$$\begin{aligned}\nabla_{\theta_i} J_i(\boldsymbol{\pi}) &= \sum_{t\ge 0} \gamma^t \mathbb{E}_{\pi}[\nabla_{\theta_i} \log \pi_i(a_{i,t} \mid h_{i,t}) G_{i,t}] \\ &= \frac{1}{1-\gamma} \mathbb{E}_{x,\boldsymbol{a}\sim d^{\pi}}[\nabla_{\theta_i} \log \pi_i(a_i \mid h_i) Q_i^{\pi}(x, \boldsymbol{a})]. \end{aligned} \tag{7.12}$$

这里 d^{π} 是集中充分信息及联合动作上的归一化折扣占用度量，J_i 仍未归一化，因此不能省去 $1/(1-\gamma)$。从 Q_i 减去合法基线可得到相应优势；相关策略须从真实联合概率重新推导得分，并检查第7.4.2节的条件，不能直接沿用个体边缘得分。

局部得分只需要行动者自身输入，集中评论家负责给这个动作赋予长期后果。对一次终止的入口教学样本，若 1 的前进概率 $p = 1/4$ 由 logit 参数生成，采到 (F, W) 并使用前节精确优势 $9/4$，得分为 $1 - p = 3/4$，梯度样本为 $27/16$。步长 0.1 将 logit 从 $\log(1/3)$ 提高到 $\log(1/3) + 27/160$，前进概率约为 0.283。这里只计算一个有限一步任务的样本更新，不额外乘折扣占用系数。

PPO 类更新令概率比 $\zeta_{i,t} = \pi_i(a_{i,t} \mid h_{i,t})/\pi_i^{\text{旧}}(a_{i,t} \mid h_{i,t})$，最大化下式的批次均值：

$$\min\{\zeta_{i,t}\widehat{A}_{i,t}, \operatorname{clip}(\zeta_{i,t}, 1-\epsilon, 1+\epsilon)\widehat{A}_{i,t}\}.$$

独立 PPO 用局部价值估优势，MAPPO 用集中状态价值估优势。该自身概率比不等于整条联合轨迹的重要性比；同一批次反复更新所有人后，对手和状态分布都可能漂移。裁剪是限制更新的机制，不是共同学习时的单调改进证明。

对可微连续动作的确定性行动者 $a_i = f_{\theta_i}(h_i)$，精确同策略梯度把得分换成 $\nabla_{\theta_i} f_{\theta_i}(h_i)\nabla_{a_i} Q_i^{\boldsymbol{f}}(x, \boldsymbol{a})$，在归一化 $d^{\boldsymbol{f}}$ 下也带 $1/(1-\gamma)$。MADDPG 从联合回放中估计这一局部方向，用目标行动者产生后继动作、TD 损失更新 Q_i；以回放分布代替 $d^{\boldsymbol{f}}$ 时得到实践中的离策略代理更新，不能未经校正称其为原始 J_i 的无偏梯度。COMA 则保留随机行动者，用式(7.9)替换优势。表7.10汇总这些差异。

方法	价值、采样与策略方向	主要成本或失效处
独立 PPO	近期联合轨迹中的局部 V_i 与裁剪得分梯度	价值遗漏他人信息；同时更新漂移
MADDPG	联合回放 Q_i 与确定性动作梯度	集中动作输入、回放失配、评论家动作梯度误差
MAPPO	近期轨迹中的集中 V_i 与裁剪得分梯度	集中状态传输、优势误差、批内复用漂移
COMA	联合 Q 与固定其他动作的候选基线	枚举自身候选；未见动作价值估错

表 7.10　策略梯度的计算接口与信息需求。合作或竞争决定使用哪个 J_i，并不由梯度算法的名字决定。

图7.4中的实线负责部署动作，虚线负责训练更新。若团队共享参数 θ，轨迹得分为 $\sum_i \nabla_\theta \log \pi_\theta(a_i \mid h_i)$，共同 J 的梯度据此汇总各人贡献。若各人的 J_i 不同，却只维护一组共享参数，必须另定加权目标或更新调度；把相冲突梯度直接平均已是一项社会选择，而不是无损的实现技巧。

7.5.2 多个学习者之间的相互适应

同一更新公式放进不同响应规则，会产生不同轨迹。对式(7.2)，令 p, q 为双方选择第一动作的概率，第一人收益为 $u(p,q) = (2p-1)(2q-1)$。投影梯度的同时更新为

$$p^{(k+1)} = [p^{(k)} + \eta(4q^{(k)} - 2)]_{[0,1]}, \qquad q^{(k+1)} = [q^{(k)} - \eta(4p^{(k)} - 2)]_{[0,1]}.$$

交替更新先算 $p^{(k+1)}$，再用它替代第二式中的 $p^{(k)}$。图7.8固定 $\eta = 0.1$、初值 $(0.7, 0.5)$，直接迭代上述规则；历史响应曲线则对截至上轮的平均对手取精确最佳响应，平局选 $1/2$。

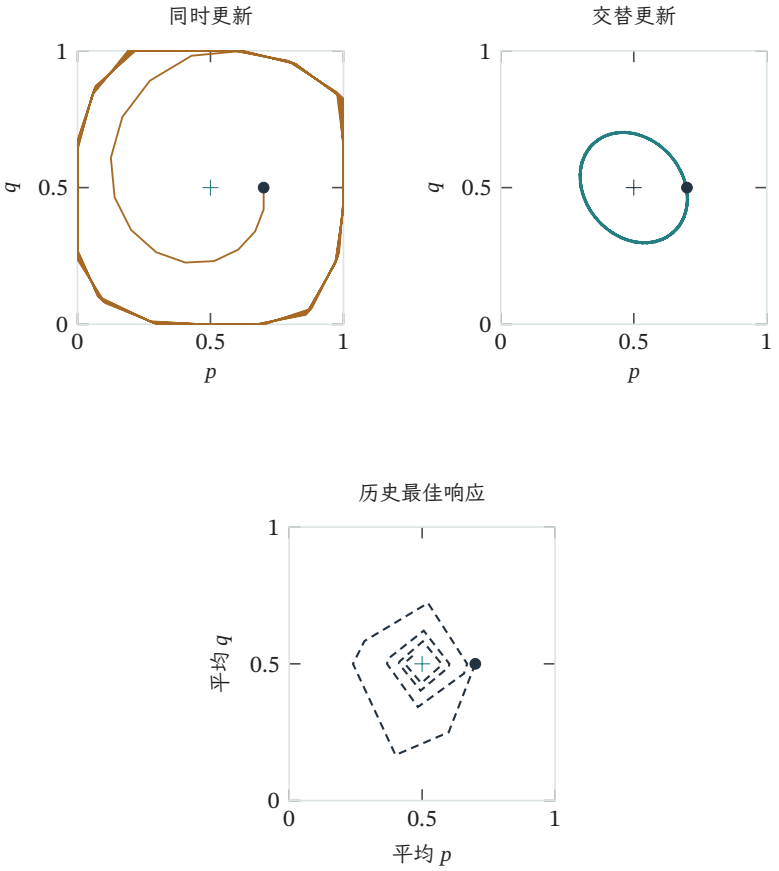


图 7.8　同一匹配硬币博弈的三种响应规则，各运行 120 次更新。曲线由图源中的递推式生成，不是实验成绩；圆点为初值，十字为均衡 $(1/2, 1/2)$。历史响应面板画累计平均策略。

未触及边界前，令 $x = p - 1/2, y = q - 1/2$，同时更新满足 $(x')^2 + (y')^2 = (1 + 16\eta^2)(x^2 + y^2)$，因而绕均衡旋转时距离还会增大。每人针对旧对方的局部改进，不推出两人共同接近均衡。历史响应比较的对象也不同：它试图对整个过去对手分布取得高收益，而不是只赢最近一个版本。

为量化这种长期比较，设第 k 轮其他行为为 $\boldsymbol{a}_{-i}^{(k)}$，定义累计外部遗憾

$$R_i^{(n)} = \max_{b_i} \sum_{k=1}^{n} \left[u_i(b_i, \boldsymbol{a}_{-i}^{(k)}) - u_i(\boldsymbol{a}^{(k)}) \right]. \tag{7.13}$$

替代动作 b_i 必须在所有轮次固定。每轮分别取最佳响应再相加，得到的是更强的动态比较，不是同一个量。混合策略版本把每轮收益写成相应期望。

令 $R_i^{(n)}(a)$ 为不取最大值的各动作累计遗憾，$[r]_+ = \max(r, 0)$。**遗憾匹配**（regret matching）用

$$\pi_i^{(n+1)}(a) = \begin{cases} [R_i^{(n)}(a)]_+ / \sum_b [R_i^{(n)}(b)]_+, & \sum_b [R_i^{(n)}(b)]_+ > 0, \\ 1/|\mathcal{A}_i|, & \text{否则}. \end{cases}$$

例如累计动作遗憾为 $(3, -1, 1)$ 时，新分布为 $(3/4, 0, 1/4)$。若全非正，本章统一回退到均匀分布。这种全信息计算需要所有未选动作的收益；已知矩阵可直接查表，只有实际动作奖励时则须探索并构造合适估计，不能直接填入未观测收益。遗憾驱动的适应规则可追溯到相关均衡学习的原始工作，外部与内部偏离的区别将在第7.7.2节验证[20]。

[20] S. Hart, A. Mas-Colell, *A Simple Adaptive Procedure Leading to Correlated Equilibrium* In Econometrica, 2000, vol. 68, no. 5, pp. 1127–1150

序贯不完全信息任务还需要避免枚举指数多的完整策略。可以在每个信息集分别评价动作，再把局部改进联系到整套策略的收益。即使自身旧策略很少到达某个信息集，也需要判断改走这条路线后该怎样行动，因此这里计算局部价值时将暂时去掉自身的先前到达概率。

这里的“反事实”与前文几种比较有不同的计算含义。规划中查询 $P(\cdot \mid s, a)$，是在固定环境规律下预测一个候选动作的后果；COMA 固定其他参与者的当前动作，对自身候选动作求策略加权平均，用作个体优势的基线；接下来 CFR 则保留对方与机会的先前到达概率，去掉自身的先前到达因子，用局部动作遗憾控制完整策略的遗憾。这些量服务于不同的决策计算，都不直接给出“同一次已发生事件若改选动作会出现哪个具体结果”的个体反事实；后者还需要第1.7.6节所述的跨动作随机结果耦合。

回到图7.3，令 $\rho_i^{\pi}(h)$ 表示到达历史 h 之前仅由 i 自己的动作产生的概率乘积，$\rho_{-i}^{\pi}(h)$ 包括对方与机会的概率乘积。令 $\mathcal{Z}$ 为终局历史集合，$P^{\pi}(z \mid ha)$ 为在 h 强制选 a 后按原策略到达 z 的后续概率，非后继终局取 0。信息集的未归一化反事实动作价值为

$$v_i^{\pi}(I, a) = \sum_{h \in I} \rho_{-i}^{\pi}(h) \sum_{z \in \mathcal{Z}} P^{\pi}(z \mid ha) u_i(z), \tag{7.14}$$

$$v_i^{\pi}(I) = \sum_a \pi_i(a \mid I) v_i^{\pi}(I, a). \tag{7.15}$$

这一价值保留了对方与机会到达各段历史的权重，没有乘自身的先前到达因子，也没有除以 $\sum_{h \in I} \rho_{-i}(h)$ 作归一化。因此它不是“已到达 I”的普通条件期望；后面的遗憾分解会说明为何需要这种加权。

例如 1 持 H，自己先过牌、2 随后下注时，假定各动作原本都均匀。该末级信息集的真实到达概率为 $\frac{1}{2} \cdot \frac{1}{2} \cdot \frac{1}{2} = 1/8$，反事实权重却为 $\frac{1}{2} \cdot \frac{1}{2} = 1/4$，删去了 1 自己的过牌因子。即使 1 很少先过牌，也应学习若来到这里是跟注还是弃牌。图7.9把被保留和被去掉的因子分开；这与 COMA 只边缘化当前自身动作不是同一个操作。



真实到达：$(1/2)\,\pi_1(K \mid H)\,(1/2)$

反事实权重：$(1/2)(1/2) = 1/4$，不计自己的前序因子

平均策略权重：$\rho_1(HKB) = \pi_1(K \mid H)$，恰好使用该因子

图 7.9　高牌分支上信息集 HKB 的两种到达权重。CFR 保留机会与 2 的因子，暂不计 1 自己的前序选择；平均行为策略反而需要按自身前序到达因子加权。

反事实遗憾最小化（counterfactual regret minimization, CFR）在每个信息集分别运行局部遗憾匹配。一次完整遍历冻结当前 $\boldsymbol{\pi}^{(k)}$，从根到叶计算到达因子，从叶到根汇总式(7.15)，再累加

$$R_i^{(k)}(I,a) = R_i^{(k-1)}(I,a) + v_i^{\boldsymbol{\pi}^{(k)}}(I,a) - v_i^{\boldsymbol{\pi}^{(k)}}(I).$$

完成遍历后，累加当前策略的平均权重，再统一生成下一轮局部策略。

表7.11从零遗憾、全部均匀策略开始，列出隐藏牌游戏的一轮结果。每行按列出的动作顺序排列，原策略的期望收益为 $J_1 = 1/8$。

行动者与信息集	动作	本轮反事实遗憾	下一轮分布
1，持 H 首次行动	(B,K)	$(3/16,-3/16)$	$(1,0)$
1，持 L 首次行动	(B,K)	$(3/16,-3/16)$	$(1,0)$
1，HKB	(F,C)	$(-3/8,3/8)$	$(0,1)$
1，LKB	(F,C)	$(1/8,-1/8)$	$(1,0)$
2，面对 B	(F,C)	$(-1/4,1/4)$	$(0,1)$
2，面对 K	(K,B)	$(-1/8,1/8)$	$(0,1)$

表 7.11　已知完整树、全遍历、同步更新的一轮 CFR 教学计算。2 的遗憾使用其自身收益 $u_2 = -u_1$，不是沿用 1 的符号。

以 HKB 行为例，$v_1(F) = -1/4$、$v_1(C) = 1/2$、当前 $v_1 = 1/8$，相减得到 $(-3/8, 3/8)$。2 面对 B 时，高低牌各有对方与机会权重 $1/4$；弃牌值为 $-1/2$，跟注值为 0，当前值 $-1/4$，所以更新为必跟注。剩余各行可按同样方式从已给终局收益复算，不需要额外游戏规则。

为何局部改进能控制完整策略偏离？有限、完全回忆博弈中有

$$R_i^{(n)} \le \sum_{I \in \mathcal{J}_i} \left[\max_a R_i^{(n)}(I,a) \right]_+ , \tag{7.16}$$

此处左侧把式(7.13)的替代动作改成一套固定完整策略。证明思路是按自身信息集的先后顺序递归分解：在某处改动动作，先计该动作在原后续策略下的增益，再把尚未计入的后续改动交给后继信息集。每个终局收益的

中间项抵消，只留下新旧策略的差。完全回忆使同一信息集有一致的自身前序行动，因此固定偏离 π_i' 的到达因子 $\rho_i^{\pi_i'}(I)$ 可提出该组历史的求和。具体得到

$$u_i(\pi_i', \pi_{-i}^{(k)}) - u_i(\boldsymbol{\pi}^{(k)}) = \sum_I \rho_i^{\pi_i'}(I) \sum_a \pi_i'(a \mid I)[v_i^{\boldsymbol{\pi}^{(k)}}(I, a) - v_i^{\boldsymbol{\pi}^{(k)}}(I)].$$

对 k 求和，固定偏离的权重不随 k 变化；内层加权平均至多为最大动作累计遗憾。又因 $0 \le \rho_i^{\pi_i'}(I) \le 1$，每项至多为该最大值的正部。最后对 π_i' 取最大即得式(7.16)。所以有限个信息集各自的遗憾为 $o(n)$，总体也为 $o(n)$。原始 CFR 给出了这一分解及局部遗憾界[21]。

全树遍历每轮成本随访问节点数增长，存储至少包括 $\sum_I |\mathcal{A}(I)|$ 个遗憾和平均策略累加量。采样 CFR 可以减少单轮访问量，但其采样概率、支持及无偏反事实估计或误差界须单独给出；任意丢弃罕见分支不自动继承全遍历结论，深度近似也增加拟合误差。

用于保证的是适当平均策略，而不是最后一轮。在完全回忆下，$\rho_i^{(k)}(I)$ 表示任取 $h \in I$ 时相同的自身前序概率乘积，不是把该因子在 I 内重复求和。平均行为策略为

$$\bar{\pi}_i^{(n)}(a \mid I) = \frac{\sum_{k=1}^{n} \rho_i^{(k)}(I) \pi_i^{(k)}(a \mid I)}{\sum_{k=1}^{n} \rho_i^{(k)}(I)}. \tag{7.17}$$

分母为零时规定任意合法分布，本章取均匀；该信息集在平均实现计划中不可达。公式来自平均自身序列实现概率：分子是“到达 I 且选 a”的平均概率，分母是“到达 I”的平均概率。逐层使用比值可恢复均匀抽取整套历史策略所产生的自身序列概率，而简单逐信息集算术平均通常不能。

例如两个版本先过牌概率分别 0.1 和 0.9，在 HKB 处跟注概率分别 1 和 0，平均跟注率应为 0.1，不是 0.5；前者使“过牌再跟注”的自身序列概率为 $0.5(0.1) = 0.05$，与两版本序列概率平均 $\frac{1}{2}(0.1 \cdot 1 + 0.9 \cdot 0)$ 相同。若两人零和且各自平均外部遗憾至多 ε，这些平均策略的总偏离间隙至多 2ε，从而各人的偏离收益也至多 2ε。第7.7.2节给出零和消去证明；该结论既不保证当前策略收敛，也不推广为一般和 Nash 保证。

[21] M. Zinkevich, M. Johanson, M. Bowling, C. Piccione, *Regret Minimization in Games with Incomplete Information* In Advances in Neural Information Processing Systems, 2007

7.5.3 自我对弈与策略群体的迭代组织

只训练来击败当前对手，会使学习者忘记更早的弱点。窄通道的一套“总让行”规则可被“总前进”利用；如果下一代又专门惩罚总前进，丢掉旧策略后就难以检查循环。自我对弈（self-play）表示利用自身或同源学习者组织对局，具体实现既可只用当前版本，也可保留历史。虚构自我对弈（fictitious self-play）则明确以历史策略分布为响应对象，用累计行为表示平均策略；深度版本中的响应与平均策略拟合都可能是近似的[22,23]。

策略空间响应预言机（policy-space response oracles, PSRO）把保留与抽样显式组织成外循环。参与者 i 的策略库为 $\mathcal{P}_i = \{\pi_i^1, \dots, \pi_i^{K_i}\}$。库索引是经验元博弈的纯策略，组合收益表 $U_i(k_1, \dots, k_m)$ 由相应策略对局估计，元混合策略 σ_i 是库索引上的分布。它与原环境中的 $\pi_i(a_i \mid h_i)$ 不是同一层对象：通常一回合先抽一次索引，再执行整套行为策略，而不是每个动作重新换网络。

图7.10展开这个外循环。固定元对手 $\boldsymbol{\sigma}_{-i}$ 后，响应训练器最大化

$$\mathbb{E}_{\boldsymbol{k}_{-i} \sim \boldsymbol{\sigma}_{-i}} J_i(\pi_i, \boldsymbol{\pi}_{-i}^{\boldsymbol{k}_{-i}}).$$

它可以调用第7.5.1节的策略梯度或价值更新；元策略可以来自零和求解器、遗憾更新或另定的群体选择规则。训练出 $\hat{\pi}_i$ 后，估计新增收益表项，扩充策略库并重新计算元策略。原始 PSRO 正是将近似响应与经验博弈求解组合起来，而不是为响应训练规定唯一底层算法[24]。

[22] J. Heinrich, M. Lanctot, D. Silver, *Fictitious Self-Play in Extensive-Form Games* In Proceedings of the 32nd International Conference on Machine Learning, 2015, pp. 805–813

[23] J. Heinrich, D. Silver, *Deep Reinforcement Learning from Self-Play in Imperfect-Information Games*, 2016, arXiv: 1603.01121, URL: https://arxiv.org/abs/1603.01121v2 (visited on 10/04/2026)

[24] M. Lanctot, V. Zambaldi, A. Gruslys, A. Lazaridou, K. Tuyls, J. Perolat, D. Silver, T. Graepel, *A Unified Game-Theoretic Approach to Multiagent Reinforcement Learning* In Advances in Neural Information Processing Systems, 2017

大规模系统采用了不同的群体维护取舍。与第7.3.1节介绍的 OpenAI Five 版本抽样相比，AlphaStar 的 league training 设置主学习者及专门寻找其弱点的不同对手角色，并从保留的历史策略中选择训练对手[25]。

OpenAI Five 主要维护共同训练的队伍，并混入历史版本对局以减少遗忘，不是每个队员各自建立独立均衡策略库。这两种组织分别强调多角色寻找弱点和在主训练过程中保留历史检验。角色更多、库更大都意味着新的对局和维护成本；它们把底层强化学习放在特定抽样及保留机制中，系统规模本身不替代完整最佳响应证据。

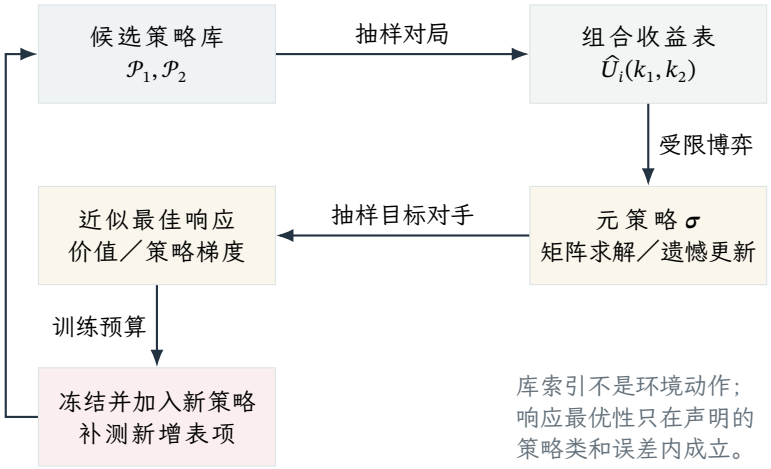


图 7.10 PSRO 的群体外循环。对局预算用于估计收益表，交互与梯度预算用于训练响应；元策略和响应器分别承接相互适应与更新计算两种选择。

用三种抽象教学策略 α, β, χ 构造零和收益表

$$\boldsymbol{U} = \begin{pmatrix} 0 & -1 & 1 \\ 1 & 0 & -1 \\ -1 & 1 & 0 \end{pmatrix}.$$

行策略 β 对当前 α 必胜，但 χ 又必胜 β，并不存在单一的最强纯策略。库只有 $\{\alpha, \beta\}$ 时，元解选择 β，在库内无法被利用；完整三策略空间中的 χ 却能获利 1。扩库后均匀混合才使各行对该混合的收益都为 0。这个算例把“赢当前对手”“解好现有收益表”“覆盖所有响应”明确分开。

若双方各有 K 个库策略、每格评价 E 局，则完整两人收益表需要 K^2E 场，新增一行一列也需相应对局；多方全组合表还会按 $\prod_i K_i$ 增长。响应网络、检查点存储和抽样数据同样消耗预算。收益表有统计误差、响应器未找到最佳策略或库遗漏关键类型时，元博弈最优不能认证完整博弈不可利用。

[25] O. Vinyals, I. Babuschkin, W. M. Czarnecki, M. Mathieu, A. Dudzik, J. Chung, D. H. Choi, R. Powell, T. Ewalds, P. Georgiev, J. Oh, D. Horgan, M. Kroiss, I. Danihelka, A. Huang, L. Sifre, T. Cai, J. P. Agapiou, M. Jaderberg, A. S. Vezhnevets, R. Leblond, T. Pohlen, V. Dalibard, D. Budden, Y. Sulsky, J. Molloy, T. L. Paine, C. Gulcehre, Z. Wang, T. Pfaff, Y. Wu, R. Ring, D. Yogatama, D. Wünsch, K. McKinney, O. Smith, T. Schaul, T. Lillicrap, K. Kavukcuoglu, D. Hassabis, C. Apps, D. Silver, *Grandmaster Level in StarCraft II Using Multi-Agent Reinforcement Learning* In Nature, 2019, vol. 575, pp. 350–354

7.5.4 学习动态的稳定性与保证对象

评价联合学习，必须同时说明更新接口、响应规则和群体。表7.12按这三项列出保证对象；一行中只替换一个模块，也可能使结论不再适用。例如从精确表格遗憾换成误差未受控的神经近似，不能保留原来的收敛定理。

更新接口	响应规则	训练群体	当前策略表现	平均策略表现	保证条件
梯度	同时追随	当前双方	可旋转或发散	不能仅由局部改进断言	另需步长、博弈与算子条件
精确响应	历史平均	历史策略	可持续变化	有限两人零和的经典虚构博弈平均可收敛	精确响应、完整有限博弈；近似误差另计
局部遗憾	同步 CFR	当前与平均	不要求收敛	适当平均的零和间隙受遗憾界控制	有限、完全回忆、正确价值或采样误差控制
梯度响应器	元策略响应	PSRO 策略库	新响应未必稳健	元混合只解受限经验博弈	收益表误差、响应误差及策略类限制均需报告

表 7.12 组合后的学习动态和保证对象。当前策略、平均行为策略、元混合策略不是可互换的报告项。

图7.11继续使用匹配硬币和同一初值，取交替更新轨迹。对任意 (p,q)，总单方偏离间隙为 $g(p,q)=|2p-1|+|2q-1|$；平均策略将 p,q 替换为历轮均值。图中还计算

$$\frac{1}{n}\max\left\{0,\ \left|\sum_k (2q^{(k)}-1)\right|-\sum_k u^{(k)},\ \left|\sum_k (2p^{(k)}-1)\right|+\sum_k u^{(k)}\right\},$$

即两人的累计平均外部遗憾正部的较大者。三条曲线由同一策略序列直接算出，当前间隙持续波动时，平均间隙仍可下降；有限步长下遗憾曲线还可能保留偏差，不应从图形形状宣称任意精度收敛。

保证中的误差应放回产生它的位置。评论家和采样误差进入收益或梯度估计；近似响应误差进入每轮与最佳响应的差；共同学习改变下一批经验分布；不完全回忆破坏信息集分解；库外策略则超出经验元博弈的比较类。只有两人零和的收益抵消，才能把双方低外部遗憾转成平均边际策略的 Nash 间隙。一般和通常只能获得联合经验分布的相关性结论，不能按同一证明宣称平均独立策略达到 Nash 均衡。

赢过训练对手、解好元博弈、抵御完整策略空间中的最佳响应，需要依次扩大验证范围，但不构成必然实现的训练阶段。恶意通信、对抗攻击和安全约束还会引入不同目标，留到第8章讨论；训练曲线稳定不能替代这些保证。

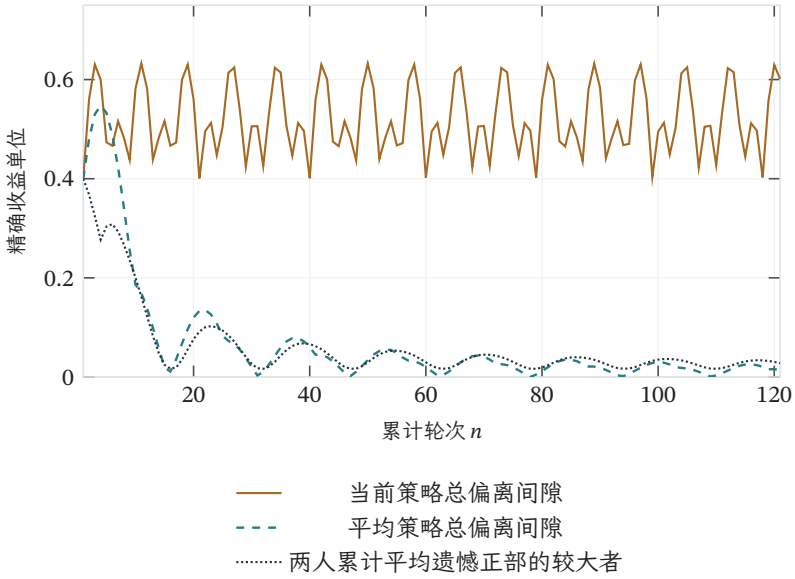


图 7.11 交替梯度教学序列的当前间隙、平均策略间隙与累计平均遗憾。所有量使用精确矩阵收益计算，图源保留递推和统计公式；不是学习基准的实验结果。

7.6 多智能体的参与者变化适配

前面通常固定一组参与者及其接口。部署时，通道可能从两人变为多人，熟悉的伙伴可能被陌生合作者替换，对手也可能换一种策略。第6章的训练分布、留出条件和适应预算仍然适用，但现在变化的是决策者。跨规模、跨伙伴和跨对手是并列的问题，一种协调成功不能同时回答三者。

7.6.1 参与者规模变化下的跨规模适配

两人策略若把对方位置拼成固定长度输入，遇到第三人就没有对应输入槽位；“1 先走、2 后走”的约定也没有规定第三人何时行动。仅交换原来两人的编号则不一样：参与者数量和物理任务都未变，只检验策略是否不必要地依赖排列。

连续控制中的参与者划分同样属于任务定义。例如，FACMAC 采用的多智能体 MuJoCo 任务按关节分组控制同一系统；更换分组或观测半径，会同时改变各人的动作与信息范围，不能只按参与者数量比较[26]。

令 $\boldsymbol{X}$ 的各行是参与者的局部特征及合法角色信息，$\boldsymbol{B}$ 为交互图的邻接矩阵，$\boldsymbol{M}$ 为置换矩阵。**置换等变性**要求策略输出随参与者重排而相应重排：

$$F(\boldsymbol{M}\boldsymbol{X}, \boldsymbol{M}\boldsymbol{B}\boldsymbol{M}^{\top}) = \boldsymbol{M}F(\boldsymbol{X}, \boldsymbol{B}).$$

[26] B. Peng, T. Rashid, C. Schroeder de Witt, P.-A. Kamienny, P. Torr, W. Boehmer, S. Whiteson, *FACMAC: Factored Multi-Agent Centralised Policy Gradients* In Advances in Neural Information Processing Systems, 2021

这不是让所有人得到相同动作，而是让物理参与者仍得到原来对应的动作。一个共享图策略可令

$$\boldsymbol{z}_i = \mathrm{Agg}_{j\in\mathcal{N}_i}\,\phi(h_i, h_j, e_i, e_j), \qquad \pi_i(\cdot) = f_\theta(h_i, e_i, \boldsymbol{z}_i),$$

其中 e_i 是可见角色，Agg 用求和、均值或对邻居集合归一化的注意力。空邻域必须定义固定合法输出，例如零向量；带身份槽位的拼接一般不满足上述性质。图7.12显示同一物理图重编号后的对应关系，进入汇聚器的只能是本轮确实获得的邻居信息。

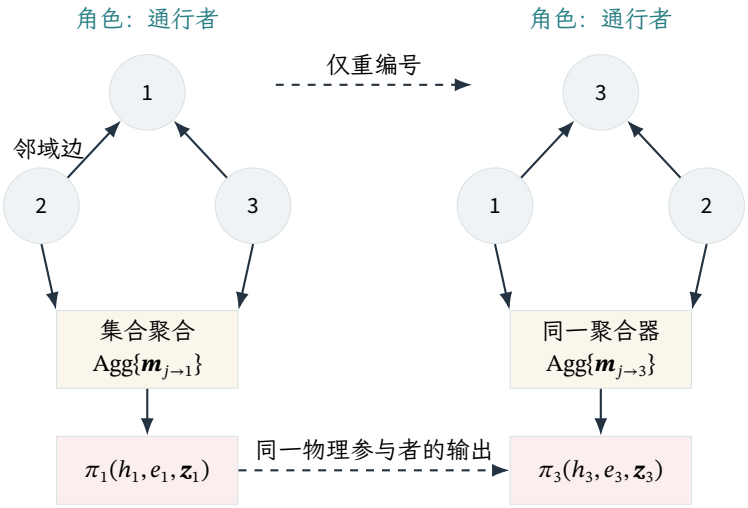


图 7.12　邻域聚合与身份置换。左图边上的消息送入中心参与者的共享聚合器；右图只把同一物理节点换编号，角色和输出随节点一起置换，不改变通行任务。

均场多智能体强化学习进一步用群体或邻域的平均行为近似逐个相互作用。例如，对具有共同离散动作语义的非空邻域，取

$$\bar{\boldsymbol{a}}_{-i} = |\mathcal{N}_i|^{-1} \sum_{j\in\mathcal{N}_i} \boldsymbol{e}(a_j),$$

其中 $\boldsymbol{e}(a_j)$ 为动作独热向量。空邻域约定 $\bar{\boldsymbol{a}}_{-i} = \mathbf{0}$，作为“无邻居”的标记，而不是概率分布。学习器估计 $Q_i(h_i, a_i, \bar{\boldsymbol{a}}_{-i})$，再用观察到的聚合行为和后继聚合预测构造 TD 目标。原始均场方法给出了相应 Q 学习及行动者—评论家机制[27]。

共享图策略的训练仍可复用联合轨迹与团队目标，只需在训练中覆盖不同图或规模，执行时按当前邻域构造输入。每轮一次边消息计算的成本为 $O(|\mathcal{E}|)$ 次消息函数调用，L 轮传递则再乘 L；表示可接受变长输入并不保证新的 m 上回报不降。求和随邻居数变化，均值会丢掉人数信息，故即使满足置换等变性，也可能需要显式计数或密度特征。

均场近似尤其需要个体影响较弱、交互可由聚合量描述等条件；“人数多”不是充分条件。窄通道只有一个关键参与者就能完全堵塞，平均前进

[27] Y. Yang, R. Luo, M. Li, M. Zhou, W. Zhang, J. Wang, *Mean Field Multi-Agent Reinforcement Learning* In Proceedings of the 35th International Conference on Machine Learning, 2018, pp. 5571–5580

率可能无法区别谁占据瓶颈。异质角色、强配合及拓扑突变都会使聚合量不充分，须在留出规模上检验这项近似。

7.6.2 未见合作者条件下的零样本协调与在线适配

把通道改为可向任一侧避让的窄路：两套独立训练的队伍分别约定都按自己的左侧、都按自己的右侧行走，各自内部可以顺利通过。混配之后，两人可能挤向同一物理侧。问题不在于任何一套策略不会行走，而在于它们建立了不兼容的约定。

Overcooked 的共享烹饪任务也区分这两种能力：同一厨房布局下，与共同训练的伙伴完成分工，并不保证与新伙伴配合成功。评价需要明确伙伴的来源及双方能否适应[28]。

本章沿用第6.1.3节的预算口径：**零样本协调**不利用新伙伴反馈进行伙伴特定的参数更新、记忆适应、类型辨识或模型选择。策略仍可读取给定角色、约定和正常控制所需的观测；在已给定任务与伙伴模型下估计当前位置，属于普通状态估计。利用伙伴动作或回报更新其行为类型，即使只发生在首个回合内、网络参数始终不变，也属于适应。

临时团队协作（ad hoc teamwork）关注没有预先共同训练或充分协调的新队伍，可按协议允许根据交互辨识和适配伙伴。具体实验必须写明是否共享左右约定、能否通信、角色是否可见、允许试探几步及试探失败的代价；任务名称本身不规定这些权限。

不同机制使用的共同信息不同。扩大训练伙伴群体需要得到多类伙伴的交互；约定或对称性处理需要知道哪些变换保持任务不变；伙伴条件策略需要部署时可观察的类型线索；在线信念更新则需要能区分候选类型的历史。Other-Play 通过对任务对称性的处理减少只在某次自我对弈中成立的任意约定，但它依赖所声明的对称性和协调条件，不保证兼容任意未知伙伴[29]。

可执行的在线方案是冻结基础策略和类型模型，在前 B 步内从获准的通行动作或消息收集证据，按第7.4.4节更新信念，再以伙伴条件价值选择动作。若允许梯度适配，另计更新次数和数据来源；零样本、仅记忆或信念适应、参数适应应分别报告，并写明回合内与跨回合的记忆保留规则。评价适应后策略时，可以继续估计物理状态，但若仍利用反馈修正伙伴类型，就仍在适应；两者无法分开时须如实计入协议。没有足够可辨识证据时，多次交互也可能无法判断两种伙伴类型。

完全对称的信息还限制角色分配。若双方使用同一确定性策略、收到同一历史，又无身份、方位或公共破缺信号，就会输出相同动作，不能保证“恰好一人前进”。独立随机化可以有机会破缺对称，但不能保证本轮必定形成指定分工。合法的公共角色信号可改变可行集合，评价时应明确给出。

[28] M. Carroll, R. Shah, M. K. Ho, T. Griffiths, S. Seshia, P. Abbeel, A. Dragan, *On the Utility of Learning about Humans for Human-AI Coordination* In Advances in Neural Information Processing Systems, 2019

[29] H. Hu, A. Lerer, A. Peysakhovich, J. Foerster, *Other-Play for Zero-Shot Coordination* In Proceedings of the 37th International Conference on Machine Learning, 2020, pp. 4399–4410

7.6.3 未见竞争者条件下的策略适应

第7.5.3节的三策略矩阵说明了针对性与稳健性的差别。面对固定 α，改用 β 把收益从 0 提高到 1；一旦对方换成 χ，同一 β 的收益又变成 -1。相反，均匀混合对三个纯对手都得 0，但也没有充分利用固定 α 的弱点。

一种对手条件策略在训练群体中学习行为表示，部署时根据可见动作、回合结果或消息更新类型信念，再选择相应响应。它的目标可以是给定对手分布下的收益，也可以加入对已知策略类的最坏情形限制，两者不能只用“适应得更快”概括。表7.13规定比较对象，并区分固定目标与反应型对手。

问题	对手、历史及允许更新	比较对象
固定对手最佳响应	目标固定；可交互观测；按给定预算更新	同一对手下可行最佳响应收益
群体内适应	见过类型的新抽样；允许历史辨识或少量更新	同预算的群体条件基线及零样本策略
跨对手泛化	未见行为类型；历史与反馈权限明确	留出类型的平均、尾部及最坏已测收益
反应型对手适应	对方可随自身行为改变；响应历史需记录	声明响应协议下的序贯收益，非固定对手值

表 7.13　竞争者适应必须同时说明类型留出、数据权限和比较对象。更换同一对手的随机种子不等于更换类型。

例如允许 20 场探测后再评价 100 场，应固定探测动作是否计分、是否重置记忆、梯度步上限及对手在 120 场中是否保持不变；这些是教学预算，不是性能结果。训练响应时用过的对局不能又冒充独立测试。对手还可能先表现温和诱导错误信念，再切换行为，或随探测继续学习。此时应回到第7.4.5节建模响应机制，不能延用固定类型识别的保证。

7.6.4 参与者变化适配的泛化与扩展边界

一次泛化测试需要一份清楚的变化表。表7.14在第6章任务关系的基础上加入参与者留出、公共约定及通信权限。训练集用于学习，验证集用于选择机制和检查点，测试集用于一次既定协议评价；将测试伙伴反复送入验证回路，会改变“未见”的含义。

同一批伙伴更换环境种子，只检验这些伙伴下的运行随机性；同一策略更换编号，最多检验身份依赖。若人数、角色、奖励和通信同时改变，失败无法仅归因于规模，成功也不能辨明究竟适应了什么。应先单因素留出，再报告明确的组合变化。泛化结论的范围不能超出实际留出的因素。

变化因素	可声明的留出方式	必须控制或记录
数量与密度	训练 2 至 4 人，测试 6 人等独立设定	通道容量、拥挤度、邻域大小，不能只改 m
身份与组合	已见类型的新排列、新搭配	角色是否同构；是否共享编号约定
合作者或对手类型	留出训练流程、策略家族或行为机制	零样本／适应预算；伙伴是否继续学习
收益关系	固定关系内的新参数，或另测关系改变	团队转竞争已改变目标，不能仅称身份泛化
通信与拓扑	留出图、延迟、带宽或接收范围	部署消息是否可得；公共信号是否保留

表 7.14　参与者适配的训练、验证与测试划分。支持内的新组合与未见行为类型需要不同的覆盖及可辨识条件。

7.7 多智能体的行为评价和验证

多智能体评价依次回答不同问题：取得了哪些收益，是否满足选定的行为标准，能否适应声明范围内的新参与者，以及付出了多少资源。基准回报、均衡偏离、交叉协调和计算成本不是同一种证据，不能压成一个没有条件的排名。

7.7.1 共同评价目标下的效用、福利与公平评价

完全合作可报告共同回报 J 及成功率；一般和应保留收益向量 $(J_1,\dots,J_m)$，再按已声明的权重计算福利 $\sum_i w_i J_i$。若目标还涉及分配，可另报告最小个体收益、等待时间分位数或收益差距，但这些统计量不自动给出规范性的公平结论。两人零和的收益和恒为 0，把它用作进步指标没有意义。

例如教学结果 $(10,0)$ 与 $(5,5)$ 的收益和同为 10，最小收益却分别为 0 和 5，个体收益的总体方差分别为 25 和 0。如果第一种结果总使同一人承担成本，团队总分会掩盖分配差异；如果角色每轮公平轮换，还应区分单回合分配和长期分配。实际报告至少给出均值、分布及失败率，并明确失败是碰撞、超时还是某人的任务未完成。

表7.15选取具体接口，而不把环境库当作单一问题。SMAC 围绕局部观测下的团队微操，地图与敌人脚本共同决定评价条件[30]。

MPE 包含不同收益和通信配置，不能把一个任务的静默动作接口推广到整个环境族。Overcooked 则应分别报告共同训练伙伴与新伙伴的配合表现，对应第7.6.2节区分的评价对象。

PettingZoo 中的石头剪刀布还须检查信息屏蔽：调用者已经保存一人的选择，不等于另一人的策略可以读取它。这个检查直接对应第7.1.3节的信息时序约定。

[30] M. Samvelyan, T. Rashid, C. Schroeder de Witt, G. Farquhar, N. Nardelli, T. G. J. Rudner, C.-M. Hung, P. H. S. Torr, J. Foerster, S. Whiteson, *The StarCraft Multi-Agent Challenge* In Proceedings of the 18th International Conference on Autonomous Agents and Multiagent Systems, 2019, pp. 2186–2188

具体接口	合作或竞争结构	可用观测	通信条件	主要指标
SMAC，3m	三个受控单位合作，对抗脚本敌人	各单位视野内信息；训练可给全局状态	原任务无额外学习消息，新增须声明	地图胜率、回报、超时率
MPE，simple_spread	多个体覆盖地标；局部碰撞项与共享项比例需指定	自身及其他实体的配置相关特征	此任务的静默体无消息；不能外推至其他 MPE 任务	覆盖距离、碰撞及所定奖励
Overcooked，cramped_room	两人完成共享烹饪与交付任务	厨房布局、物品及参与者状态的指定编码	原动作接口无自由语言频道	交付数、团队回报、分工及等待
PettingZoo，rps	两人石头剪刀布，零和	本轮选择在双方提交前相互隐藏	无显式消息；AEC 调用次序不等于看见先行动作	各自收益及偏离间隙
多智能体 MuJoCo，分组 HalfCheetah	不同关节组共同控制同一系统	分组关节特征及指定观测半径	消息或额外关节信息需另列	回报、稳定性、推理时延

表 7.15 具体任务接口决定可比较的指标。软件版本、地图、观测包装器、奖励配置和回合上限均属于复现协议。

连续多智能体控制须按第7.6.1节的划分记录关节分组及每组可见信息，不能只写“MuJoCo”。参与者数量和观测半径改变后，控制与协调条件也随之改变。

这些接口的动作粒度、回合长度和奖励尺度不同，原始分数不能直接相加。评价时应复用部署权限，不能给待测策略额外全局状态或免费通信。若训练采用奖励塑形，最好同时报告原任务指标及实际优化回报，免得把塑形收益当作真正完成任务的证据。

7.7.2 行为标准下的偏离收益、遗憾与可利用性验证

固定其他完整策略时，参与者 i 的单方偏离收益定义为

$$\delta_i(\boldsymbol{\pi}) = \sup_{\pi_i' \in \Pi_i} J_i(\pi_i', \boldsymbol{\pi}_{-i}) - J_i(\boldsymbol{\pi}).$$

策略类 Π_i 必须保留原信息与行动权限，并包含当前 π_i，所以 $\delta_i \geq 0$。两人零和时，本章以 $g = \delta_1 + \delta_2$ 表示总偏离间隙；有些软件把 $g/2$ 称为可利用性，报告时须注明约定。

对匹配硬币取 $p = 0.7, q = 0.4$，当前 $u_1 = -0.08$。1 改为第二动作可得 0.2，故 $\delta_1 = 0.28$；2 改为第二动作使 1 得 -0.4，2 由 0.08 升至 0.4，故

$\delta_2 = 0.32$。总间隙 0.6，按半间隙约定则为 0.3。均匀对手下取得零回报，不足以辨认这样的可利用性。

第7.5.2节给出了生成低遗憾策略的机制，下面直接从定义验证它支持什么结论。

定理 7.6　阶段遗憾与联合经验分布　固定有限阶段博弈重复 n 轮，记实际联合动作为 $\boldsymbol{a}^{(k)}$，联合经验分布为 $\hat{q}_n(\boldsymbol{a}) = n^{-1}\sum_{k=1}^{n}\mathbf{1}\{\boldsymbol{a}^{(k)} = \boldsymbol{a}\}$。若每人对每个固定替代动作的累计外部遗憾均不超过 $n\varepsilon$，则 $\hat{q}_n$ 满足 ε 粗相关均衡约束。若对每对动作 a_i, b_i，内部遗憾

$$\sum_{k=1}^{n}\mathbf{1}\{a_i^{(k)} = a_i\}[u_i(b_i, \boldsymbol{a}_{-i}^{(k)}) - u_i(\boldsymbol{a}^{(k)})] \le n\varepsilon,$$

则 $\hat{q}_n$ 满足每对动作采用未条件化偏离约束的 ε 相关均衡。

证明　固定 i, b_i。将其外部遗憾不等式除以 n，并按相同联合动作合并项，得到

$$\sum_{\boldsymbol{a}}\hat{q}_n(\boldsymbol{a})[u_i(b_i, \boldsymbol{a}_{-i}) - u_i(\boldsymbol{a})] \le \varepsilon.$$

这正是在收到任何动作建议之前改成固定 b_i 的粗相关偏离约束。它对每个 i, b_i 成立，故得到第一项结论。

对内部遗憾同样除以 n 并合并，只保留实际建议为 a_i 的轮次，得到

$$\sum_{\boldsymbol{a}_{-i}}\hat{q}_n(a_i, \boldsymbol{a}_{-i})[u_i(b_i, \boldsymbol{a}_{-i}) - u_i(a_i, \boldsymbol{a}_{-i})] \le \varepsilon.$$

这正是“仅在收到 a_i 建议时改为 b_i”的未条件化约束。它对每一对动作成立，即为所声明的近似相关均衡。整个推导保留联合频率，没有假设各人的经验独立。 ■

若希望把第二个约束写成收到 a_i 后的条件收益，右端应除以 $\hat{q}_{n,i}(a_i)$；罕见建议的条件误差可能很大。零概率建议无需检查条件期望。多个建议同时映射到替代动作时，相加的误差还会累积；不能把每对动作的 ε 不加说明地称为任意交换映射的同一 ε 界。

相关经验分布不能用边缘乘积替代。若两种协调约定 (L, L) 和 (R, R) 各出现一半，经验分布从不失配，而各边缘都均匀；把它们独立相乘后，失配概率却变成 $1/2$。在一般和中，低遗憾控制的是这种保留相关性的分布，并不通常控制边际平均策略的 Nash 偏离。

定理 7.7　零和平均策略的鞍点间隙　有限两人零和矩阵 $\boldsymbol{A}$ 中，第 k 轮混合策略为 $\boldsymbol{x}^{(k)}, \boldsymbol{y}^{(k)}$。若双方按期望收益计算的累计外部遗憾分别不超过 $n\varepsilon_1, n\varepsilon_2$，令 $\bar{\boldsymbol{x}} = n^{-1}\sum_k \boldsymbol{x}^{(k)}$、$\bar{\boldsymbol{y}} = n^{-1}\sum_k \boldsymbol{y}^{(k)}$，则

$$\max_{\boldsymbol{x}} \boldsymbol{x}^{\top}\boldsymbol{A}\bar{\boldsymbol{y}} - \min_{\boldsymbol{y}} \bar{\boldsymbol{x}}^{\top}\boldsymbol{A}\boldsymbol{y} \le \varepsilon_1 + \varepsilon_2.$$

左侧等于 $(\bar{\boldsymbol{x}}, \bar{\boldsymbol{y}})$ 的总单方偏离间隙。

证明　记实际各轮期望收益之和为 $S = \sum_k (\boldsymbol{x}^{(k)})^{\top}\boldsymbol{A}\boldsymbol{y}^{(k)}$。对第一人，外部遗憾界和对 $\boldsymbol{y}$ 的线性性给出

$$n\max_{\boldsymbol{x}} \boldsymbol{x}^{\top}\boldsymbol{A}\bar{\boldsymbol{y}} - S \le n\varepsilon_1.$$

第二人最大化的是负收益，故其界为

$$S - n\min_{\boldsymbol{y}} \bar{\boldsymbol{x}}^{\top}\boldsymbol{A}\boldsymbol{y} \le n\varepsilon_2.$$

相加后 S 严格抵消，再除以 n 即得所述不等式。另一方面，平均策略的两项偏离收益分别是

$$\max_{\boldsymbol{x}} \boldsymbol{x}^{\top}\boldsymbol{A}\bar{\boldsymbol{y}} - \bar{\boldsymbol{x}}^{\top}\boldsymbol{A}\bar{\boldsymbol{y}}, \qquad \bar{\boldsymbol{x}}^{\top}\boldsymbol{A}\bar{\boldsymbol{y}} - \min_{\boldsymbol{y}} \bar{\boldsymbol{x}}^{\top}\boldsymbol{A}\boldsymbol{y}.$$

它们非负且相加正好为左侧，因此每一项也不超过 $\varepsilon_1 + \varepsilon_2$。 ■

若使用实际纯动作及其实际遗憾，亦可把纯动作视为单纯形顶点应用此论证；若只有期望遗憾界，要作高概率经验声明还需集中界。一般和的两人收益不是相反数，中间实际收益项无法如此消去，所以不能照此推出 Nash 结论。

有限扩展式博弈可把完整确定性应对计划看成纯策略，并在完全回忆下用式(7.17)恢复平均实现计划。随机博弈则必须明确检验完整策略偏离、状态条件偏离还是给定轨迹上的局部替换。改变策略会改变后续状态访问，不能把原轨迹上各步动作遗憾相加，就宣布约束了任意完整策略的收益。表7.16将这些验证对象并列。

若响应搜索只找到 $\tilde{\pi}_i$，其真实偏离收益至多为 δ_i，所以“没有找到强响应”不等于不存在强响应。只有另外证明搜索误差 η_i，即最佳响应值至多比已找到值高 η_i，才得到对应上界；有限对局估值还要加统计不确定性。响应训练、响应筛选和最终收益评价最好用分离数据，防止把搜索过程的偶然高分当作真实漏洞，也防止用搜索失败认证不可利用。

指标	对象与计算权限	可支持的结论
固定对手回报	对某对手的重复对局	该对手分布下的收益，非均衡认证
阶段外部／内部遗憾	固定阶段收益；需替代动作收益或受控估计	联合经验的 CCE ／相应 CE 约束
平均策略间隙	两人零和；完整比较类的双方遗憾或响应	该平均策略及策略类下的偏离界
当前策略可利用性	固定当前对方，分别搜索并评价最佳响应	精确响应给间隙；近似响应通常只揭示下界

表 7.16 不同评价量的对象、访问要求与结论范围。平均策略保证不能替当前策略认证。

7.7.3 基于交叉对局与留出参与者的泛化验证

self-play 评价同一训练系统产生的配合，cross-play 把独立训练种子的策略混配，主要检查约定兼容性。群体内留出排除某些训练伙伴或组合，检验支持内泛化；未见行为类型测试则排除整个策略家族或生成机制，检验更强的分布变化。四者的对局都可以很多，但样本数量不能替代留出定义。

图7.13使用明确的两约定教学任务：双方选择同一约定得团队分 10，不同得 0；独立训练来源 A、B 固定约定 L，来源 C 固定约定 R。行列都是来源，而非同一网络不同回合的随机数。主对角都得 10，A、B 对 C 却得 0，因此只看主对角会误判协调能力。

	A：L	B：L	C：R
A：L	10	10	0
B：L	10	10	0
C：R	0	0	10

同约定得 10，异约定得 0；深边框为同来源策略配合。

图 7.13 两约定教学任务的精确交叉配合矩阵。每格均为团队分，深边框标同来源对角；A、B 的 L 约定与 C 的 R 约定不兼容，数值由规则直接得到，不是实测成绩。

测试协议应先固定训练群体、检查点选择和每种伙伴的对局预算。对每个留出伙伴先报告零样本结果，再在预设预算 $B \in \{0, 5, 20\}$ 等教学网格上测适应后表现；横轴计实际交互，梯度步和记忆是否重置另列。反复查看测试对手结果再选检查点，相当于把测试对手用于开发，应重新留出而不是仍称其未见。

均匀抽取图中九格的平均分为 50/9，最差格为 0；仅取三格对角的平均为 10。不同伙伴分布会改变加权平均，故需同时给出矩阵、权重、平均及最坏已测表现。有限对局不能穷尽全部对手，最坏已测值也不是完整策略空间的最坏值；群体平均成绩不提供不可利用性上界。

7.7.4 固定样本、通信与计算预算下的效率评价

一次环境转移同时包含 m 个动作时，联合环境步数增加 1，参与者动作数增加 m。两者都可报告，但不能为不同算法选择有利口径。训练梯度步还要记录批次大小、复用次数和每步更新了几个网络；对手查询按响应训练及评价实际发起的对局计，不能藏进“免费环境”。部署成本则包括消息字节数、同步轮次、单人及系统动作时延。

表7.17固定每人 A 个离散动作、图边集 $\mathcal{E}$ 和消息维度 d_c，比较结构性成本。采样量统一用联合步数 N 报告，但不同方法达到某一回报所需的 N 必须实际测量，不能由表中的计算阶数推导。

结构	人数与动作计算	采样及训练权限	训练通信／存储	部署推理与通信
联合价值枚举	m 人，A^m 组合	N 联合步；集中输入	联合转移、动作与价值表或网络	若集中选动作，须具备实时集中权限
VDN ／ QMIX	局部比较 mA 次	N 联合步；QMIX 混合器用状态	联合 TD 目标及训练反传	m 次局部网络；无必需执行消息
集中评论家、局部行动者	每人一次动作输出	N 联合步；声明评论家状态／动作输入	回放或近期轨迹及集中特征	局部推理；共享参数不等于共享观测
图消息策略	m 节点、$\lvert\mathcal{E}\rvert$ 条边	N 联合步；合法训练图	消息及历史按实现记录	$L\lvert\mathcal{E}\rvert d_c$ 量级消息元素，L 轮同步
PSRO 群体	双方各 K 个库策略	响应样本加收益表对局；权限继承响应器	K^2 表项及多个检查点	回合抽索引再执行；未必同时运行全部网络

表 7.17 资源口径中的训练与部署区分。复杂度项只描述所列操作，不等于总运行时间或样本复杂度定理。

图7.14用一个串行通信模型说明跨规模代价：每条有向边处理一条消息需 0.01 毫秒，计算节点动作另需 $0.05m$ 毫秒。全连接边数为 $m(m-1)$，每人最多 4 个出邻居时边数取 $m\min(4, m-1)$，故

$$T_{\text{全连}}(m) = 0.05m + 0.01m(m-1),$$
$$T_{\text{局部}}(m) = 0.05m + 0.01m\min(4, m-1).$$

这是指定串行模型下的解析时延，不是硬件测试。$m = 20$ 时两者分别 4.8 和 1.8 毫秒；真实并行设备、拥塞和同步代价可能改变结果。

参数共享可减少模型存储，却仍需为不同局部历史计算动作；集中信息可能减少估计难度，却增加训练传输；通信可能提高协调回报，却增加部

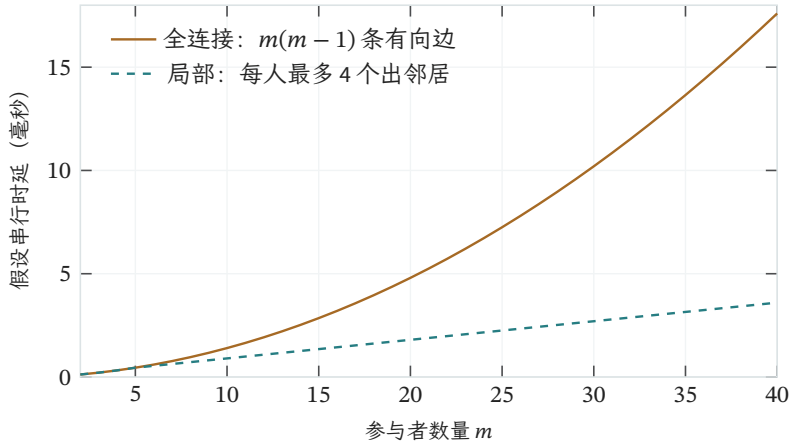


图 7.14 固定串行消息处理假设下的教学扩展曲线。全连接和最多 4 邻居的局部交互使用同一单节点及单边成本；稀疏图节省通信，但不保证保留任务所需信息。

署时延。比较新规模时还要控制拥挤程度、瓶颈容量和信息权限，否则资源增长与任务变难混在一起，曲线无法解释。

7.7.5 行为评价与复现所需的协议信息

复现一次多智能体结果，需要恢复的不只是参数和种子，还包括谁同谁在何种权限下交互。表7.18把容易改变结论的实现项落到训练或执行环节。尤其是退出参与者：继续输出占位动作、移出联合动作空间、仅屏蔽损失，三者会改变不同对象，不能共用一个未解释的“死亡屏蔽”开关。

协议项	必须记录的内容	主要影响环节
参数共享与身份	共享哪些模块；编号、角色编码及重排规则	参数梯度汇总与执行约定
集中状态与屏蔽	评论家输入；合法动作信息来自何处	训练权限及执行动作分布
死亡、退出与终止	占位观测、动作、损失屏蔽；全局或个体终止	价值目标、占用统计和人数
回放与版本	来源检查点、窗口、概率字段、校正与采样权重	联合经验的目标匹配
对手与伙伴抽样	库版本、保留及淘汰、抽样概率、是否在线学习	训练和评价的参与者分布
通信	发送／接收权限、载荷、时序、延迟、带宽	部署可行性与成本
回报与评价	奖励尺度、塑形、回合上限、偏离类及间隙约定	行为标准和比较口径

表 7.18 多智能体结果的最小协议信息。每一项都可能改变被评价的策略或环境，不能只附超参数表。

此外应保存伙伴与对手的生成流程、策略库及检查点标识、选择检查点所用的验证参与者、各组合评估场数。训练初始化、环境随机性和伙伴抽样随机性应使用可追踪的独立随机源。若报告 5 次独立训练、每次 1000 局，不能把 5000 局当成 5000 个独立训练样本；同一检查点或同一适应链上的对局往往相关，区间估计应保留训练运行和伙伴层级。

无法恢复的第三方对手、外部游戏版本或消息服务条件应明确列为限制。复现材料可以支持“在这些保存的伙伴及接口下重现”，却未必支持“对所有未知参与者都成立”。评价的可信程度取决于声明、协议和证据是否指向同一个对象。

7.8 本章小结

窄通道中的一次让行，把本章的三个起点连在一起：收益关系规定什么叫做好，信息权限规定动作能依赖什么，其他参与者是否学习则决定行为后果会不会随之改变。团队最优、极小极大、单方偏离稳定与社会分配目标不能互换；集中训练也不能把执行时不可见的信息变成合法输入。

联合经验必须保留动作、消息和参与者来源，边缘动作都出现过并不代表联合效果可识别。估计时可以同时保留联合动作、个体替代、局部组合、伙伴类型与响应依赖；更新时再组合价值或梯度计算、相互适应规则和群体组织。单次局部改进不保证联合动态稳定，局部贪心的一致性不保证整张价值表可表达，近似响应和有限策略库也不保证完整博弈不可利用。

验证要把对象分开：外部与内部遗憾约束不同的联合经验分布，零和条件下才能进一步控制适当平均策略的鞍点间隙；当前策略不因此自动收敛。训练对手上的胜率、留出伙伴的协调、跨规模表现及资源成本也各有边界；利用伙伴反馈更新记忆或类型属于适应，不能只因参数固定就记为零样本。只有将行为标准、参与者范围、信息契约和预算一起报告，结果才可解释。第8章从行为要求这一并列维度讨论风险、扰动和安全约束；已有性能证据不会自动成为安全保证，涉及多方时还须保留本章的联合行为与信息条件。

第 8 章

可信强化学习

一台导航机器人平均很快到达终点，是否就适合投入运行？如果少数回合会严重延误，平均时间没有说明后果有多坏；如果地面变湿，原来学到的制动规律可能失效；如果机器人靠紧急保护器才没有撞上障碍，成功记录说明的是整个受保护系统，而不是候选策略本身。判断行为是否可接受，需要比平均回报更完整的要求，也需要与要求相匹配的证据。

本章沿用第 1 章的策略与轨迹对象，以及第 2、3 章的规划和学习工具。风险敏感决策改变随机结果的比较方式，鲁棒决策改变要求覆盖的环境范围，安全约束改变允许选择的行为集合。这是三个可以组合的视角，不是一条从简单到高级的方法演进链。另一个独立问题是：即使算法声称优化了这些要求，有限试验或模型证明究竟支持什么结论？回答这一问题时，必须把策略、学习算法和实际执行系统分开。

图 8.1 将这三类要求并列放在共同设定之下。每一类要求都需要相应证据，才能参与同一任务中的方案比较；组合后的结论还要保留各自的条件与适用边界。

8.1 行为要求与保证对象

仍以从起点驶向终点的移动机器人为对象。为隔离不同问题，可以固定路线、初始位置和动力学，只改变到达时间的分布，观察偶发严重延误；也可以固定策略与目标，仅改变地面摩擦，观察制动距离；或者固定环境，把一块原本可以穿越的地带声明为危险区，检查策略是否满足新约束。启用一个会替换危险动作的保护层，又改变了实际执行机制。这四种比较分别追问结果分布、环境变化、行为可行性和保证对象，不能共用一个“成功率提高”的答案。

本章的离散导航示意沿用宽 4、高 3 的网格、起点 $(1,1)$、终点 $(4,3)$ 和障碍 $(2,2)$。涉及具体概率时，会另行声明是基准滑移模型，还是为手算而抽象出的路线选择任务；后者不冒充整个随机网格的精确解。连续控制仍写作 $\boldsymbol{x}_{t+1} = \boldsymbol{A}\boldsymbol{x}_t + \boldsymbol{B}\boldsymbol{u}_t + \boldsymbol{w}_t$，其中状态可以包含位置和速度，扰动 $\boldsymbol{w}_t$ 的范围必须单独给定。

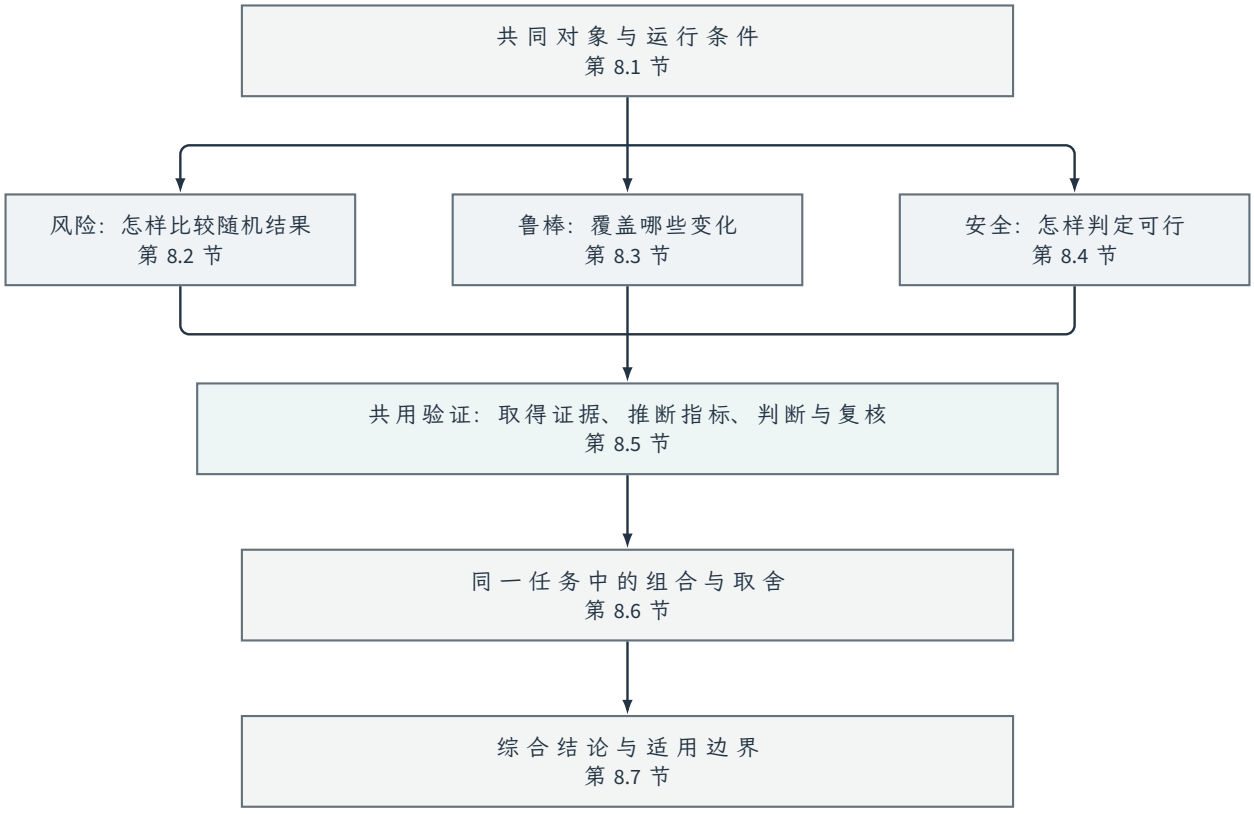


图 8.1 可信强化学习的章内关系。共同设定向三个并列分支提供对象和运行条件，分支向共用验证过程提供要求与待验证策略；验证结论用于判断组合方案的取舍，并形成有条件的综合结论。箭头表示这些依赖，不表示风险、鲁棒与安全必须依次执行。

定义 8.1 回报、损失、成本与失败事件 对轨迹 $\tau = (s_0, a_0, r_0, s_1, \ldots)$，回报为 $G(\tau) = \sum_{t\geq 0} \gamma^t r_t$，目标 $J(\pi) = \mathbb{E}_\pi G$ 不作归一化。损失 $L(\tau)$ 表示需要抑制的后果，数值越大越差；它可以是累计延误，也可以是 $-G$，但必须明确选择。安全成本 $c_{i,t} \geq 0$ 记录第 i 类危险暴露或损害，其累计量为 $C_i(\tau) = \sum_{t\geq 0} \gamma^t c_{i,t}$。失败事件 $F_H \subseteq \{\tau\}$ 则是一个真假条件，例如在前 H 次动作中至少碰撞一次。有限时域任务的求和截至 $H-1$，不折扣时直接使用有限和。

到达效率可以进入奖励，严重延误可以进入损失，靠近危险区的时间可以进入成本，碰撞可以定义失败事件。同一次碰撞也可以同时增加损失和成本，但这些量不是同一个指标：成本可能区分事故的次数与严重程度，事件指示量 $\mathbf{1}\{F_H\}$ 只记录是否发生，尾部损失则比较最坏的一部分结果有多严重。

风险准则（risk criterion）规定怎样用整个随机结果的分布比较策略，而非只比较均值。**鲁棒要求**（robustness requirement）规定同一策略必须应对哪些机制或输入变化。**安全约束**（safety constraint）规定什么行为才算

可行，例如累计成本不超过预算、碰撞概率低于阈值，或始终不离开某个集合。**可靠性**（reliability）在这里指指定对象在声明的运行条件下持续满足要求的程度；它必须通过统计或模型证据来论证，不能由算法名称直接赋予。

表 8.1 把三种常见的保证对象分开。固定策略的随机轨迹来自环境和动作采样；重复训练还包含数据次序、初始化和探索造成的差异。保护层启用后，系统执行的动作可能与策略提出的动作不同，此时碰撞记录针对的是策略与保护层的组合。

保证对象	随机性来源	评价单位	要求作用时机
固定策略 π	初态、转移、观测、动作采样	一个完整运行回合	策略冻结后的部署
学习算法	训练种子、训练数据、探索与优化	一次完整训练及其输出	训练中或输出策略上
策略与保护层	上述运行随机性，以及保护器输入与执行误差	实际执行系统的一回合	所有受保护执行时刻

表 8.1　保证对象决定抽样单位。每行还须固定初态分布、观测接口、时域、交互权限及其他参与者的范围，不能把训练曲线平稳等同于系统安全。

运行范围可以写成一份协议：从哪些位置启动，允许什么摩擦变化，传感器误差多大，能否主动试探，其他机器人按什么规则行动，以及保护器是否启用。对这些条件不作限定，“策略可靠”没有确定的真假含义。

还要区分两个概率。$p = \mathbb{P}_{\pi}(F_H)$ 回答“这个策略运行时多常失败”；置信水平 $1-\delta$ 回答“重复采用这套取证与推断程序，所得界有多大比例覆盖真实 p”。前者是行为性质，后者是统计程序的性质。例如 $p \le 0.01$ 和置信水平 0.95 不能交换位置。阈值、运行范围和允许的推断错误率都应在验证前确定，否则根据结果反复修改标准会改变声明的含义。

8.2 风险敏感决策

假定环境模型和运行范围暂时固定，问题是怎样比较其内部的随机后果。一个决策者可以在出发前评价整段累计损失，承诺按这个评价执行后续方案；也可以要求到达每个历史时都按同一种条件风险继续决策。两种要求的差别发生在时间结构上。某些累计风险能够通过状态增广递推，逐阶段递归风险也有自己的 Bellman 方程，但两者不因此成为同一个目标。

8.2.1 累计结果分布上的风险决策

考虑两个教学策略：平稳策略损失恒为 1，偶发严重损失的策略以 0.95 概率损失 0、以 0.05 概率损失 20。它们的期望损失都是 1，方差却分别为 0

和 $0.05\times 20^2-1^2=19$。只看均值无法区分两者。若最坏的 5% 回合需要人工接管，那么这一差别正是决策者关心的后果。

不同准则表达不同偏好。最小化 $\mathbb{E}u(L)$ 时，在损失取值范围上递增的凸函数 u 会加重严重损失。例如，对上述非负损失取 $u(l)=l^2$，数值变为 1 和 20，但也改变了损失单位；若允许负损失，平方函数就不再处处递增。均值–方差准则 $\mathbb{E}L+\lambda\,\mathrm{Var}(L)$ 用 $\lambda\ge 0$ 调节离散程度，方差同时惩罚向均值两侧的偏离，而且需要二阶矩存在。分位数只询问某个概率位置上的损失阈值；尾部均值还考察阈值之外有多坏。不能因为这些准则都偏离期望，就认为它们会给出相同排序。

定义 8.2　损失上尾的 VaR 与 CVaR　对可积损失 L 及分位水平 $0<\alpha<1$，令

$$\mathrm{VaR}_\alpha(L)=\inf\{z:\mathbb{P}(L\le z)\ge\alpha\},\tag{8.1}$$

$$\mathrm{CVaR}_\alpha(L)=\inf_{\eta\in\mathbb{R}}\left\{\eta+\frac{\mathbb{E}(L-\eta)_+}{1-\alpha}\right\},\tag{8.2}$$

其中 $(x)_+=\max(x,0)$。风险价值（value at risk, VaR）是分位点；条件风险价值（conditional value at risk, CVaR）是最差 $1-\alpha$ 概率质量的平均损失，必要时只取分位点处概率原子的一部分。

为什么优化式会找到分位点？记分布函数 $F(z)=\mathbb{P}(L\le z)$，把式 (8.2) 花括号内函数记为 $\phi(\eta)$。每个 $(L-\eta)_+$ 都是凸函数，所以 ϕ 凸。阈值从左、右移动时，恰等于阈值的样本贡献不同，从而

$$\phi'_-(\eta)=\frac{F(\eta-)-\alpha}{1-\alpha},\qquad \phi'_+(\eta)=\frac{F(\eta)-\alpha}{1-\alpha}.$$

凸函数在左右导数夹住 0 处取得最小值，条件就是 $F(\eta-)\le\alpha\le F(\eta)$。分位点 $q=\mathrm{VaR}_\alpha(L)$ 满足这个条件；存在平坦区间时最优阈值可以不唯一。将 q 代回目标，得到可直接处理概率原子的公式

$$\mathrm{CVaR}_\alpha(L)=\frac{\mathbb{E}[L\mathbf{1}\{L>q\}]+q\big(F(q)-\alpha\big)}{1-\alpha}.\tag{8.3}$$

右侧从严格大于 q 的结果取全部质量，再从 q 处补足到 $1-\alpha$。这正是一般损失分布下 CVaR 的处理方式[1]。

对开头两个策略，$\mathrm{VaR}_{0.95}$ 分别为 1 和 0，而 $\mathrm{CVaR}_{0.95}$ 分别为 1 和 20。后者若误用 $\mathbb{E}[L\mid L\ge 0]$，会得到 1，遗漏最差 5% 的含义。图 8.2 把概率画成离散质量：平稳策略在 1 处的原子只抽取 5% 质量，另一策略在 20 处的全部 5% 质量就是尾部。图中均值重合，分位点和尾部却不同。

[1] R. T. Rockafellar, S. Uryasev, *Conditional Value-at-Risk for General Loss Distributions* In Journal of Banking & Finance, 2002, vol. 26, no. 7, pp. 1443–1471

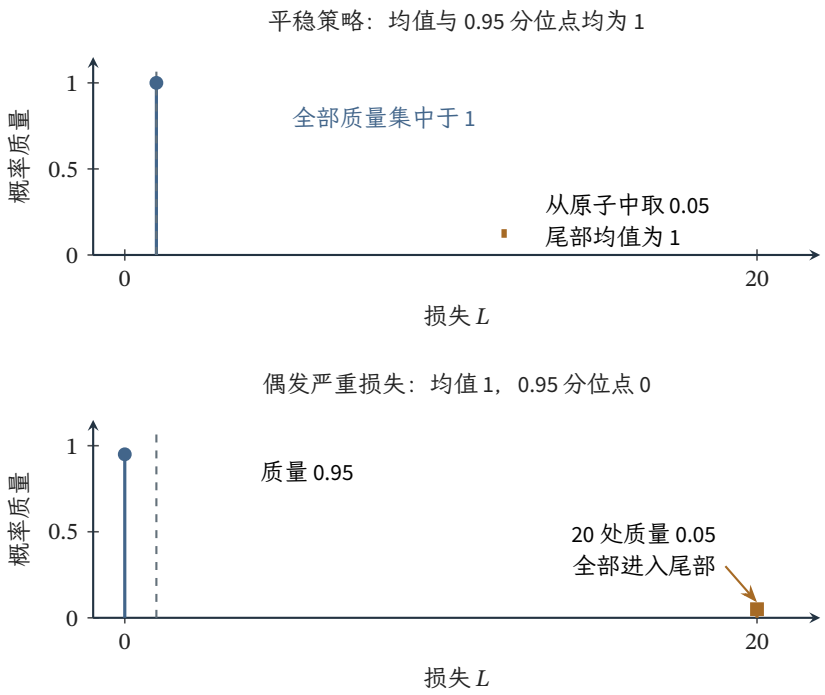


图 8.2 两个教学损失分布，横轴为无量纲损失，纵轴为概率质量。粗实线和实心点表示原子，虚线标均值；旁边的小条标明用于计算 CVaR 的最差 5% 质量，不是连续概率密度。

若模型未知但能够运行当前策略，可以直接优化累计损失的静态 CVaR。设策略为 π_θ，一回合损失为 $L(\tau)$，定义

$$\Phi(\theta,\eta)=\eta+\frac{1}{1-\alpha}\mathbb{E}_{\tau\sim\pi_\theta}(L(\tau)-\eta)_+.$$

对于与参数无关的环境、可微且支持不随参数突变的随机策略，在可交换微分与期望的条件下，轨迹概率的对数导数是 $\sum_{t=0}^{H-1}\nabla_\theta\log\pi_\theta(a_t\mid h_t)$。固定阈值求导给出

$$\nabla_\theta\Phi=\frac{1}{1-\alpha}\mathbb{E}\left[(L-\eta)_+\sum_{t=0}^{H-1}\nabla_\theta\log\pi_\theta(a_t\mid h_t)\right]. \tag{8.4}$$

阈值的一个次梯度为 $1-(1-\alpha)^{-1}\mathbb{P}(L>\eta)$；在 $L=\eta$ 处可以按 $[0,1]$ 中的权重分配质量。这是在联合目标上更新阈值和策略，不是假定有限样本分位数已经精确。

算法 8.1 累计 CVaR 的轨迹更新

输入： 分位水平 α，时域 H，批量 n，步长序列，初值 $\theta^{(0)}, \eta^{(0)}$
输出： 候选策略及其阈值；可靠性另用留出数据验证

for $k = 0, \dots, K-1$ **do**
  冻结当前参数，用 $\pi_{\theta^{(k)}}$ 独立启动 n 条轨迹，记录逐步损失并计算 L_j
  在旧参数、旧阈值上，用式 (8.4) 的样本均值计算 $\widehat{\boldsymbol{g}}_\theta$
  计算 $\widehat{g}_\eta = 1 - \frac{1}{n(1-\alpha)} \sum_j \mathbf{1}\{L_j > \eta^{(k)}\}$，按需处理阈值处原子
  $\theta^{(k+1)} = \theta^{(k)} - \beta_k \widehat{\boldsymbol{g}}_\theta$，$\eta^{(k+1)} = \eta^{(k)} - \zeta_k \widehat{g}_\eta$
end for

这个更新如何改变行为？设每回合出发时以概率 $p = \mathrm{sigmoid}(\theta)$ 选偶发严重损失策略，否则选平稳策略。对 $0 \le p \le 1$，最差 5% 质量由 $0.05p$ 的损失 20 和 $0.05(1-p)$ 的损失 1 组成，故 CVaR 为 $1 + 19p$。在 $p = 1/2$、最优阈值 $\eta = 1$ 处，精确策略梯度为 $19p(1-p) = 4.75$；损失最小化的一步更新使 θ 减小，从而降低选择高尾部损失路线的概率。这是解析教学计算，不是训练结果。

一批数据需要 nH 次交互及相应的策略求导，存储整批轨迹需要与 nH 成正比的空间；排序求经验分位数另需 $O(n \log n)$，阈值次梯度本身只需 $O(n)$。当 $n(1-\alpha)$ 很小时，梯度主要依赖极少数回合，甚至整批都没有出现关键尾部事件。用同批数据选策略再报告其尾部估计还会引入选择偏差。换成模型轨迹可以减少真实交互，却把模型在罕见区域的误差带入目标；这些误差不会被 CVaR 公式自动消除。百分位风险约束中的策略梯度和行动者–评论家方法也遵循“估计风险、更新策略、调整约束”的联系，其局部收敛条件不能解释成任意神经网络训练的全局最优保证[2]。

已知有限时域模型时，静态目标还可以保留为动态规划问题，而不改变成逐阶段 CVaR。以累计损失 $L = \sum_{t=0}^{H-1} \gamma^t \ell_t$ 为例，增广状态记录已经积累的损失 z。对事先固定的 η，令

$$
\begin{aligned}
W_H^\eta(s, z) &= (z - \eta)_+, \\
W_t^\eta(s, z) &= \min_{a \in \mathcal{A}(s)} \mathbb{E}\big[W_{t+1}^\eta(s', z + \gamma^t \ell_t) \mid s, a \big].
\end{aligned}
\tag{8.5}
$$

再在出发前最小化 $\eta + (1-\alpha)^{-1} \mathbb{E}_{s_0 \sim \rho_0} W_0^\eta(s_0, 0)$。这里允许策略依赖时间、状态和已观察的累计损失，且用模型对联合后继状态与损失求期望。若损失支持离散且有限，可枚举可达 z；若 z 连续，离散化或插值会增加状态规模并引入误差。阈值是事前承诺的一部分，途中不能把它重置为新的条件分位数。另一类增广方法保存尾部概率预算；其原论文将参数记为尾部质量，换成本章记号时应使用 $1 - \alpha$[3]。

[2] Y. Chow, M. Ghavamzadeh, L. Janson, M. Pavone, *Risk-Constrained Reinforcement Learning with Percentile Risk Criteria* In Journal of Machine Learning Research, 2018, vol. 18, no. 167, pp. 1–51

[3] Y. Chow, A. Tamar, S. Mannor, M. Pavone, *Risk-Sensitive and Robust Decision-Making: A CVaR Optimization Approach* In Advances in Neural Information Processing Systems, 2015

示例 8.3 静态 CVaR 的时间不一致 设 $H=2$ 且不折扣。$t=0$ 只有一个虚拟动作，损失为 0，随后进入可观察的分支 A 或 B，概率分别为 0.1 与 0.9。$t=1$ 在 B 只有一个动作，损失固定为 10；在 A 可以选 safe，损失 12，也可以选 risky，损失以 0.9 概率为 0、以 0.1 概率为 20。决策者在 $t=0$ 选择并承诺一个完整条件策略，在到达 A 后执行约定动作。

取 $\alpha=0.9$。承诺 safe 时，总损失分布为 $10(0.9), 12(0.1)$，CVaR 为 12。承诺 risky 时，分布为 $0(0.09), 10(0.9), 20(0.01)$，最坏 10% 由全部 1% 的 20 和 9% 的 10 组成，所以

$$\mathrm{CVaR}_{0.9}(L_{\text{risky}}) = \frac{0.01\times 20 + 0.09\times 10}{0.1} = 11.$$

事前准则严格选择 risky。但一旦到达 A，重新最小化条件 CVaR，safe 与 risky 的数值分别为 12 与 20，因而严格选择 safe。环境和可选动作没有改变，改变的是条件化之后用于定义尾部的概率质量。

这个反例展示的是事前承诺与途中重新优化的冲突，而不是决策者看不到分支。静态 CVaR 在原物理状态上通常不能直接套用普通 Bellman 递推；式 (8.5) 保留累计信息与事前目标，正是为避免丢掉这层承诺。若运行要求本来就希望每个历史都重新按相同风险规则判断，则应明确采用下一小节的动态目标。

8.2.2 逐阶段条件风险下的决策

到达 A 后，决策者已知道 B 没有发生，因而可以要求未来方案只按 A 下的后果比较。**条件风险映射**（conditional risk mapping）把下一阶段的不确定损失转成当前信息下的风险数值；这个数值对当前已知历史是可计算的，对更早时刻仍可以是随机变量。令 $\mathcal{F}_t$ 表示时刻 t 已知的信息，映射 ρ_t 把 $\mathcal{F}_{t+1}$ 可测损失变成 $\mathcal{F}_t$ 可测量。条件 CVaR 就是在式 (8.2) 中使用条件期望，并允许阈值依赖当前历史。

定义 8.4 嵌套风险与时间一致性 取归一化 $\rho_t(0)=0$ 的一步条件风险映射。对阶段损失 ℓ_t，定义

$$\mathcal{R}_t = \rho_t(\ell_t + \gamma \mathcal{R}_{t+1}), \qquad \mathcal{R}_H = 0.$$

这称为嵌套风险（nested risk），即把后一步风险当作当前待评价的未来损失。动态风险族是时间一致的（time-consistent），如果对任意 $u<v$ 和两个损失序列，它们在 $u,\dots,v-1$ 相同，且 v 时刻的条件风险几乎处处满足 $\mathcal{R}_v \le \widetilde{\mathcal{R}}_v$，就有 $\mathcal{R}_u \le \widetilde{\mathcal{R}}_u$。

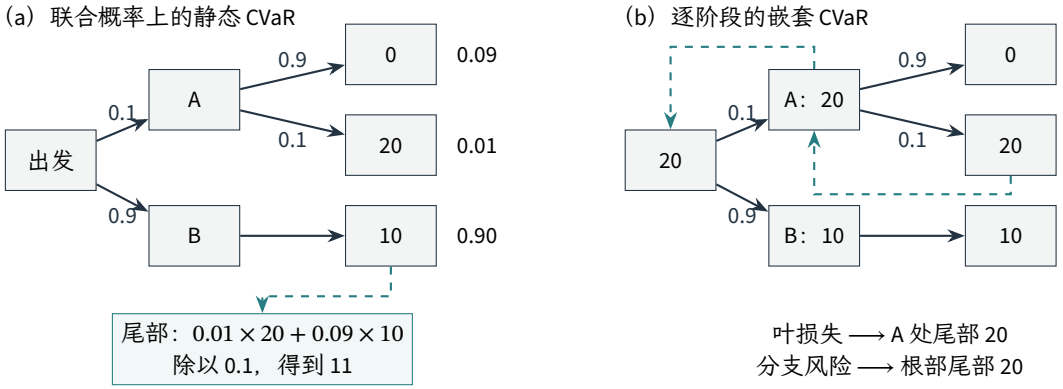


图 8.3 同一教学决策树的两种风险汇总，均取 $\alpha = 0.9$、$H = 2$ 且不折扣。图中展示承诺 risky 的分支；实线表示随机转移，带文字的回传箭头表示风险计算。safe 只需将 A 的两个叶节点替换为固定损失 12。

时间一致性要求“以后在每个可能历史下都不更差”的方案，在相同的前段损失下，不应被更早的评价颠倒排序。若各 ρ_t 单调，把 v 时刻的不等式逐层代入递归即可传到 u，因此上述嵌套构造满足这一条件。这里比较的是条件风险的排序，不是保证每条轨迹都无损失。动态风险与 Markov 风险表示的系统论述见原始工作[4]。

[4] A. Ruszczyński, *Risk-Averse Dynamic Programming for Markov Decision Processes* In Mathematical Programming, 2010, vol. 125, no. 2, pp. 235–261

在示例 8.3 中，每层都使用 $\alpha = 0.9$ 的条件 CVaR。在 A 汇总 risky 的叶节点后得到 20，safe 得到 12；在 B 得到 10。再对分支风险 20(0.1), 10(0.9) 汇总，risky 的嵌套风险为 20，而 safe 为 12。图 8.3 并排展示两种计算：静态准则保留叶节点的联合概率，嵌套准则先把各分支变成风险数值。嵌套风险选择 safe 不是静态 CVaR 求解器变得更准确，而是评价对象已改变。

要把递归风险写成状态价值，状态必须保留条件分布和风险映射需要的信息。设当前动作确定后，一步损失 $\ell(s,a)$ 已知，$\rho_{s,a}$ 评价后继状态上的随机量。若映射满足对当前已知量的平移等变性，便可把这一已知损失移到映射外。对有限时域 Markov 风险问题，向后归纳得到

$$V_t(s) = \min_{a \in \mathcal{A}(s)} \{\ell_t(s,a) + \rho_{t,s,a}(\gamma V_{t+1}(s'))\}, \qquad V_H = 0. \tag{8.6}$$

若一步损失也随机，须把 $\ell_t + \gamma V_{t+1}$ 一起放进对应联合分布的风险映射。若风险水平依赖剩余预算或历史，该信息也要进入状态。动作优化这里采用确定性 Markov 选择；若允许随机动作，要另外约定风险是在随机化之前还是之后评价，再建立相应算子。

定理 8.5 折扣风险算子的压缩性 设状态与可行动作集有限且非空，阶段损失有界，$0 < \gamma < 1$。每个实值一步风险映射 $\rho_{s,a}$ 满足单

调性及常数平移等变性 $\rho_{s,a}(X+b)=\rho_{s,a}(X)+b$。对已经按声明的风险问题建立的算子

$$(TV)(s)=\min_{a}\{\ell(s,a)+\rho_{s,a}(\gamma V(s'))\},$$

有 $\|TV-TW\|_\infty\le\gamma\|V-W\|_\infty$。因而该算子有唯一固定点，反复应用 T 从任意有限初值收敛到该点。

证明 令 $\varepsilon=\|V-W\|_\infty$。对所有后继状态，$\gamma W-\gamma\varepsilon\le\gamma V\le\gamma W+\gamma\varepsilon$。单调性把不等式传入 $\rho_{s,a}$，平移等变性把两端的常数移出，得到

$$\rho_{s,a}(\gamma W)-\gamma\varepsilon\le\rho_{s,a}(\gamma V)\le\rho_{s,a}(\gamma W)+\gamma\varepsilon.$$

记每个动作的花括号表达式为 $q_V(s,a)$ 和 $q_W(s,a)$，则 $|q_V-q_W|\le\gamma\varepsilon$。对所有动作的下界取最小值，得 $(TV)(s)\ge(TW)(s)-\gamma\varepsilon$；取上界的最小值，得反向界。因此所需无穷范数界成立。

令 $V^{(k+1)}=TV^{(k)}$。相邻迭代差至多为 $\gamma^k\|V^{(1)}-V^{(0)}\|_\infty$；对这些差求几何级数，说明序列是有限维完备空间中的 Cauchy 序列，故收敛到某个 $V^\star$。压缩性蕴含连续性，将迭代式取极限得到 $TV^\star=V^\star$。若 $W^\star$ 也是固定点，则 $\|V^\star-W^\star\|_\infty\le\gamma\|V^\star-W^\star\|_\infty$；由于 $\gamma<1$，只能有 $V^\star=W^\star$。再次应用压缩性得 $\|V^{(k)}-V^\star\|_\infty\le\gamma^k\|V^{(0)}-V^\star\|_\infty$。 ■

证明没有用正齐次性；把折扣留在 $\rho(\gamma V)$ 内部即可。固定点对应哪个决策目标，则仍依赖时间一致的风险定义、充分的状态表示和允许策略类，不能靠压缩性倒推这些建模条件已经满足。

以已知有限模型上的条件 CVaR 价值迭代为例，冻结 $V^{(k)}$，对每个 (s,a) 列出后继值 $\gamma V^{(k)}(s')$ 及概率，排序后从最大值开始累计 $1-\alpha$ 质量，按式 (8.3) 计算风险，再加 $\ell(s,a)$ 并对动作取最小值。迭代到残差 $\|TV^{(k)}-V^{(k)}\|_\infty\le(1-\gamma)\epsilon$ 时，压缩界与三角不等式给出 $\|V^{(k)}-V^\star\|_\infty\le\epsilon$。在两阶段树上，从终端 0 开始，A 的回传立即得到 $\min(12,20)=12$，B 得到 10，根部再得到 12，完成一次可复核的向后计算。

记状态数为 m、每个状态最多 b 个动作，稠密转移下每次排序式更新的代价为 $O(bm^2\log m)$，存储模型需 $O(bm^2)$。只有指定状态动作的随机采样接口时，可以用独立后继批次近似这些条件分布，但单个后继样本的风险一般不是总体风险的无偏估计。若每步近似算子误差一致不超过 e，迭代误差满足 $\Delta_{k+1}\le\gamma\Delta_k+e$，长期误差上限为 $e/(1-\gamma)$。风险策略梯度需要与嵌套目标一致的风险权重；分布评论家需要估计相应条件后果分布。只把期望评论家的输出换成一个尾部分位数，不能省去对新目标与采样关系的推导。

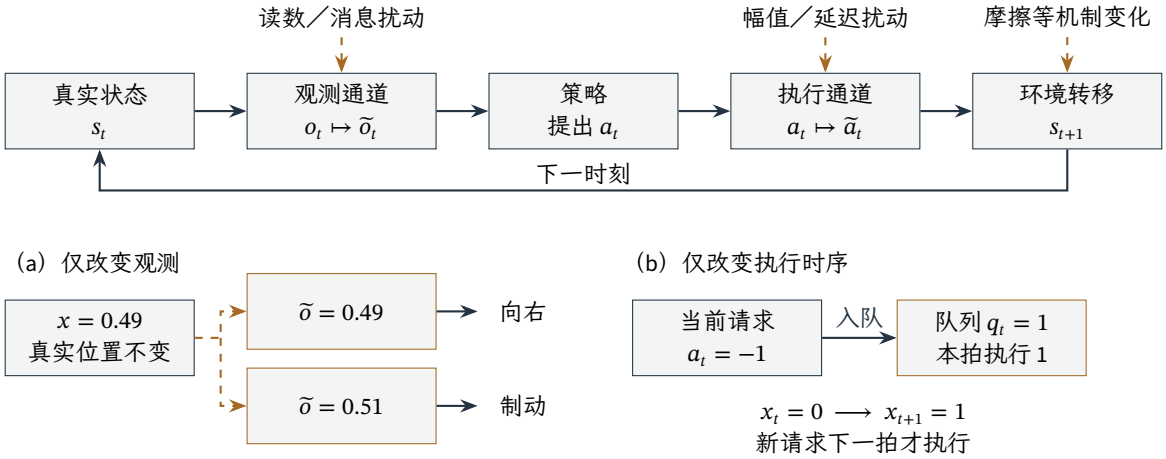


图 8.4 扰动进入交互闭环的三个位置。实线传递状态、观测与动作，虚线表示不同扰动权限。下方两个局部面板分别只突出观测误差和执行延迟，二者均不等于直接改变当前真实位置。

8.3 不确定环境下的鲁棒决策

风险敏感决策可以在同一个已知概率模型内讨论；鲁棒决策则问该模型、观测或动作执行发生变化时，策略还能否维持要求。图 8.4 固定一个闭环，把变化分成三个作用位置。改变摩擦直接改变真实状态转移；修改传感读数不必改变物理状态；削弱制动力则发生在请求动作与实际执行之间。对抗训练是一种搜索不利变化的求解手段，不是与这三种位置并列的第四种不确定对象。

8.3.1 环境机制变化下的鲁棒决策

估计得到摩擦系数 0.6，与知道真实系数位于 $[0.4, 0.8]$，提供的是不同信息。前者给出一个标称模型 $\widehat{P}$，后者给出一族可能的转移核 $\mathcal{U}$。本小节先固定奖励 R 和初态分布 ρ_0，只允许转移核变化，以免不确定对象含混。

定义 8.6 最坏情形回报 对模型集合 $\mathcal{U}$，固定策略 π 的鲁棒回报为

$$J_{\mathrm{rob}}(\pi) = \inf_{P \in \mathcal{U}} J_P(\pi), \qquad \max_{\pi} J_{\mathrm{rob}}(\pi).$$

集合 $\mathcal{U}$ 描述允许的环境，而不是轨迹中随机转移结果的集合。若奖励或初态也不确定，应把它们与 P 一起列入模型集合。

若 $\mathcal{U} = \mathcal{U}(\mathcal{D})$ 来自数据，还需区分模型假设与统计覆盖事件 $\{P_{\text{真}} \in \mathcal{U}(\mathcal{D})\}$。在该事件上，任何被评价策略都有 $J_{P_{\text{真}}}(\pi) \geq \inf_{P \in \mathcal{U}} J_P(\pi)$。若集合以至少 $1 - \delta$ 的概率覆盖真实模型，才可把这个确定性集合内结论转成带置信水平的声明。集合过小可能漏掉真实模型，过大则可能造成不必要的保守。鲁棒 MDP 中的集合结构与数据置信区域需要一起指定[5]。

[5] W. Wiesemann, D. Kuhn, B. Rustem, *Robust Markov Decision Processes* In Mathematics of Operations Research, 2013, vol. 38, no. 1, pp. 153–183

要沿用 Bellman 递推，需要进一步限定集合如何分解。状态–动作矩形性（state-action rectangularity）指 $\mathcal{U} = \prod_{s,a} \mathcal{U}_{s,a}$：任意从每个局部集合中选一个转移分布，组合起来仍是允许的模型。与之对应的动态对手可以观察当前状态和已选动作，在 $\mathcal{U}_{s,a}$ 中选择下一步分布，没有跨状态或跨时间共享的剩余扰动预算。此时鲁棒 Bellman 算子为

$$(T_{\mathrm{rob}}V)(s) = \max_{a \in \mathcal{A}(s)} \left\{ R(s,a) + \gamma \min_{p \in \mathcal{U}_{s,a}} \sum_{s'} p(s')V(s') \right\}. \tag{8.7}$$

外层选择动作，内层选择该动作下最不利的后继分布，顺序表达了对手的信息权限。若对手必须在看到动作前承诺跨动作耦合的参数，就不能不加说明地使用同一算子。

定理 8.7　矩形鲁棒 Bellman 算子的压缩性　设状态动作有限，可行动作非空，奖励有界，$0 < \gamma < 1$，每个 $\mathcal{U}_{s,a}$ 都是概率单纯形中的非空紧集。在状态–动作矩形不确定集和上述对手权限下，式 (8.7) 在无穷范数下是 γ 压缩映射。

证明　令 $\varepsilon = \|V - W\|_\infty$。对任意概率向量 p，

$$\left| \sum_{s'} p(s')V(s') - \sum_{s'} p(s')W(s') \right| \le \sum_{s'} p(s')\varepsilon = \varepsilon.$$

记内层最小值为 m_V, m_W。上式对集合中每个 p 都成立，故 $\sum pV \ge \sum pW - \varepsilon \ge m_W - \varepsilon$，取最小值得 $m_V \ge m_W - \varepsilon$。由于紧性保证 W 的最小点 p_W 存在，$m_V \le \sum p_W V \le m_W + \varepsilon$。于是 $|m_V - m_W| \le \varepsilon$。加入相同的 $R(s,a)$ 并乘以 γ，每个动作的表达式相差至多 $\gamma\varepsilon$。对各动作的上下界分别取最大值，得到

$$(T_{\mathrm{rob}}W)(s) - \gamma\varepsilon \le (T_{\mathrm{rob}}V)(s) \le (T_{\mathrm{rob}}W)(s) + \gamma\varepsilon.$$

对状态取最大绝对差，结论成立。固定点存在、唯一及价值迭代收敛由定理 8.5 证明中的 Cauchy 序列与唯一性论证直接得到。 ■

这段压缩证明只检查数值算子。矩形性另负责把局部选择接成同一个合法的全局环境。在固定点处，每个状态可选择一个外层最优动作，每个状态动作可选择一个内层最差分布；矩形性使这些分布能够共同组成 $P^\star \in \mathcal{U}$。固定平稳 Markov 策略后也能作同样选择：将外层动作最大化换成按 $\pi(a \mid s)$ 平均，保留每个动作下的内层最小化，相应评价算子给出该策略在矩形模型族中的最坏回报。历史依赖策略则须保留它所用的记忆，不能直接套用这个状态评价算子。有限时域的逐步归纳及无限时域的折扣极限把局部选择与动态对手问题连接起来；有限时域模型族还须允许各时

刻的局部分布独立组合，不能从空间上的矩形性推得时间上的自由变化。这种连接不能移植到任意耦合集合。

实际求解时，若集合由一个置信多面体给定，内层是线性目标 $\sum pV$ 的线性规划；若只是两个后继状态的概率区间，检查端点即可。教学例中后继价值为 10 与 0，$\gamma = 0.9$，当前奖励 0，好状态概率 $p \in [0.7, 0.9]$，该动作的鲁棒备份为 $0.9 \times 0.7 \times 10 = 6.3$，标称 $p = 0.8$ 时则为 7.2。若另一动作有确定后继价值 7.5，其备份为 6.75，鲁棒动作选择会改变。迭代过程冻结旧价值、逐对求内层最小值、再取外层最大值。设一次内层优化代价为 $C_{\text{内}}$，每轮需 $O(mbC_{\text{内}})$；内层残差、模型集估计和价值逼近误差应分别记录。

示例 8.8　共享参数不能随状态独立取坏值　一个两阶段教学任务以相同概率从 s_1, s_2 启动，各只有一个动作，第一步奖励 0。下一步到达成功状态得到奖励 1，失败状态得到 0，随后终止。整个环境共享一个固定未知参数 $\vartheta \in [0,1]$，成功概率分别是 $p_1 = \vartheta$ 与 $p_2 = 1 - \vartheta$。对任意合法环境，初态平均回报都为 $\gamma(p_1 + p_2)/2 = \gamma/2$。如果只保留每个概率各自属于 $[0,1]$，逐状态最坏选择会取 $p_1 = p_2 = 0$，得到回报 0；然而不存在同时产生这两个概率的 ϑ。

图 8.5 中的斜线才是真实允许的参数组合，方形是矩形化后的扩大集合。扩大集合上的算子可以严格收敛，但求得的是更保守的另一个问题。若共享参数可被观测历史逐渐识别，还会产生信息价值；此时要保留参数信念或相关历史，而不是把每次访问都解释成对手重新任意改变参数。

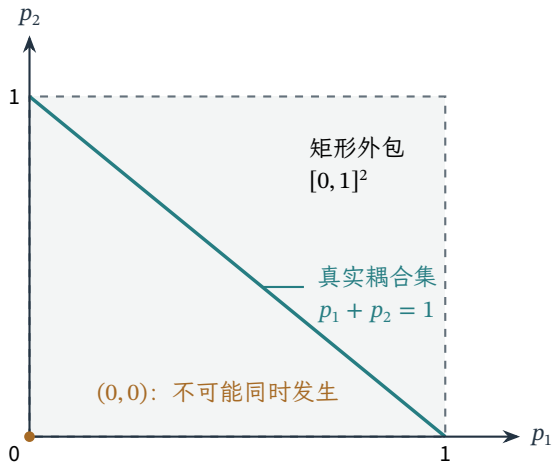


图 8.5　教学耦合集 $\{(p_1, p_2) : p_1 + p_2 = 1\}$ 与矩形外包 $[0,1]^2$。方形左下角给出局部最坏选择，却不属于共享参数模型。坐标是两状态的成功概率。

“分布鲁棒”也需要指出分布是谁的分布。它可以表示后继状态转移分布 $p(\cdot \mid s, a)$ 的不确定性，也可以表示随机环境参数 ϑ 的分布 ν 不确定，后者优化 $\inf_{\nu \in \mathfrak{U}} \mathbb{E}_{\vartheta \sim \nu} J_{P_\vartheta}(\pi)$。一个模型在每回合开始抽取并保持不变，与每

一步重新抽取，通常不是同一个过程。Xu 与 Mannor 的分布鲁棒 MDP 通过参数分布的嵌套集合约束编码概率信息，并给出相应的状态分解与求解条件；不能据此把任何参数分布歧义集都逐状态拆开[6]。

[6] H. Xu, S. Mannor, *Distributionally Robust Markov Decision Processes* In Advances in Neural Information Processing Systems, 2010

表 8.2 按不确定对象比较集合。对于其他参与者造成的转移变化，是否允许任意局部对手还要与第 7 章的联合行为模型一致；识别未知参数后适应，则回到第 6 章的任务推断问题。

不确定对象	集合来源与矩形条件	内层求解及保证范围
参数 $\vartheta \in \Theta$	物理区间或联合置信集；共享参数通常耦合状态	在 Θ 上优化；覆盖整个参数族，不自动支持局部备份
转移分布 $p \in \mathcal{U}_{s,a}$	距离球、矩或似然约束；须说明各对之间能否自由组合	线性、凸或专门分布优化；只覆盖声明集合
参数分布 $\nu \in \mathfrak{U}$	对模型参数随机性的矩、支持或概率质量约束	对分布求最坏期望；需说明参数抽取时机及依赖

表 8.2　三种不同层次的不确定性。置信覆盖是构造集合的额外统计性质，不由“鲁棒”或“分布鲁棒”的名称保证。

8.3.2 观测信息受扰下的鲁棒决策

现在固定真实动力学与路线，只让传感器报告发生变化。记真实状态为 s_t，原始观测为 o_t，受扰观测为 $\widetilde{o}_t$，策略只能使用 $\widetilde{h}_t = (\widetilde{o}_0, a_0, \dots, \widetilde{o}_t)$。一个具体威胁模型可以规定：扰动者在原始观测产生后、策略采样动作前，选择 $\widetilde{o}_t \in \mathcal{B}_\epsilon(o_t) = \{o : \|o - o_t\|_\infty \le \epsilon\}$；它能看到当前原始观测和策略参数，但不能看到未来噪声或尚未采样的动作。若还有总预算 $\sum_t \|\widetilde{o}_t - o_t\| \le B$，剩余预算就是对手状态的一部分。不同权限对应不同最坏情形，不能只写“加了扰动”。

图 8.4 的观测面板给出一个一维教学反例：真实位置 $x = 0.49$ 不变，策略在读数小于 0.5 时向右，否则制动。读数 0.49 与 0.51 都可能由 $|\widetilde{o} - x| \le 0.02$ 产生，却触发不同动作。这里被修改的是策略输入，不是机器人已经移动到 0.51。若仅测试 $\widetilde{o} = 0.48, 0.49$，两个测试都通过也没有检查到允许集合另一侧的动作切换。

一种可执行的训练循环是固定当前策略，按允许预算搜索使回报较小的观测序列，再在这些受扰轨迹上更新策略，并用未参与更新的扰动规则与启动条件检验。以无记忆的确定性连续动作策略和可微的一步价值代理为例，可从 o_t 初始化，反复进行

$$\widetilde{o}^{(j+1)} = \mathrm{Proj}_{\mathcal{B}_\epsilon(o_t)}\left(\widetilde{o}^{(j)} - \xi \nabla_{\widetilde{o}} \widehat{Q}(s_t, \pi_\theta(\widetilde{o}^{(j)}))\right).$$

这一步以降低奖励价值为方向，使用训练时可得的真实状态或其估计；它不是保证找到整条轨迹最坏观测的算法。随机策略应对动作分布下的期望

价值求导，不能把概率分布当作一个动作直接输入 $\widehat{Q}$；有记忆策略还须保留受扰历史对内部状态的影响。生成样本后，用第 3 章的策略更新提高受扰回报，新的参数又改变下一轮内层目标。若每步搜索 $K_{攻}$ 次，梯度计算代价约为普通采样的该倍数，且对手梯度与策略梯度应分开计算。

鲁棒状态估计把读数转成与误差模型相容的状态集合；历史方法利用动力学与多次观测消除一部分歧义；输入保护则修复或拒绝可疑读数。三者都需要额外假设：误差界有效、动力学足够准确，或可疑输入能够识别。若修复器输出 $\widehat{o}$ 仍有误差 $\|\widehat{o}-o\|\le e$，对确定性连续动作策略，还需它在该区域满足 Lipschitz 条件，才有动作误差上界 $\|\pi(\widehat{o})-\pi(o)\|\le L_{\pi}e$；还需价值或闭环动力学的敏感性界，才能把它转成回报或安全界。阈值策略在切换面附近不满足这样的连续性估计。信念和历史状态的构造见第 4 章。

设真实最坏回报为 $J_{\min}=\inf_{\nu\in\mathcal{N}}J(\pi,\nu)$，近似攻击找到 $\widehat{\nu}$，则 $J_{\min}\le J(\pi,\widehat{\nu})$：攻击样本的回报对最坏回报只是一个上界。只有另外证明内层误差 $J(\pi,\widehat{\nu})-J_{\min}\le e_{攻}$，才能得到 $J_{\min}\ge J(\pi,\widehat{\nu})-e_{攻}$。因此，针对若干攻击表现良好，是测试证据；覆盖全部允许输入的保证还需要搜索完备性、可验证的误差界或形式化分析。

8.3.3 动作执行受扰下的鲁棒决策

策略请求制动，并不意味着制动力立即足量施加。记请求动作为 a_t，实际执行动作为 $\widetilde{a}_t$。幅值误差可以写成 $\widetilde{a}_t=a_t+e_t$、$\|e_t\|\le\epsilon_a$，但执行器饱和还需把结果限制在物理可行输入内；篡改要规定攻击者何时读取请求动作，延迟则要规定队列及最大滞后。图 8.4 的执行面板突出这种区别。

固定一拍延迟时，物理系统实际满足 $x_{t+1}=f(x_t,a_{t-1},w_t)$。仅给出 x_t 和当前请求 a_t，无法确定下一步分布，因为队列里的旧请求仍会执行。增广状态 $z_t=(x_t,q_t)$、$q_t=a_{t-1}$，则

$$x_{t+1}=f(x_t,q_t,w_t),\qquad q_{t+1}=a_t. \tag{8.8}$$

若 w_t 在给定 z_t,a_t 后按固定核抽取，该式恢复马尔可夫转移。例如教学系统 $x_{t+1}=x_t+\widetilde{a}_t$，在 $x_t=0,q_t=1$ 时即使请求 $a_t=-1$，下一步仍为 $x_{t+1}=1$；该请求只把队列改为 -1。忽略队列会把一次正确的制动请求错误地解释成模型预测失效。

已知执行误差集合时，鲁棒规划可以在每个请求动作下计算最坏后继价值

$$\inf_{e\in E(s,a)}\mathbb{E}\big[V\big(f(s,a+e,w)\big)\big]. \tag{8.9}$$

其中 $E(s,a)$ 是状态 s 下请求动作 a 允许的执行误差集合，e 由扰动者选择；w 是按已声明条件分布抽取的其他随机扰动，f 给出实际动作 $a+e$ 对应的状态转移，V 是后继价值。该表达式先选择执行误差，再对随机扰动求

期望；备份还须加入即时奖励和折扣，并按实际对手权限组织动作优化。若即时奖励也依赖执行误差，应将它放入同一个内层最坏情形优化。

扰动对手训练用模型或真实交互搜索不利执行动作，其近似内层误差仍受上一小节的限制。反馈补偿则根据实际运动估计误差并修正下一次请求；它需要足够快的测量、可辨识的误差和剩余控制能力，不能补偿任意延迟或完全失去制动能力。

若执行通道在给定当前状态动作后与更早历史条件独立，且条件分布 K 固定，可以将它积分进有效转移核

$$P_{\mathrm{eff}}(s' \mid s, a) = \int P(s' \mid s, \tilde{a})\, K(d\tilde{a} \mid s, a).$$

有记忆的延迟、相关误差或对手剩余预算不能如此无损消去；执行动作不可见时，还可能需要对队列或误差状态作历史推断。表格规划的状态数也会从 m 扩大到 $m|\mathcal{A}|$，多拍队列可进一步指数增长。

数据记录应同时保存请求动作、执行动作和干预原因。学习物理模型 $P(s' \mid s, \tilde{a})$ 需要实际动作；学习包括执行通道的模型 $P_{\mathrm{eff}}(s' \mid s, a)$ 则使用请求动作并固定通道协议。二者混用会把通道变化归因于错误的对象。即便补偿提高了平均回报，修正后的实际动作是否保持安全状态，仍要由下一节的约束与保护条件判断。

8.4 安全约束下的策略学习与保护

“减少危险”还不是一个可检验的要求。机器人在危险区域停留的平均时间不超过预算、整段导航的碰撞概率不超过阈值、任何时刻都不越过边界，允许的行为并不相同。表 8.3 按判定方式区分三类约束。训练数据来自哪里、是否知道动力学、能否部署保护器，决定怎样满足约束，却不会改变约束本身的类别。

约束对象	个别轨迹能否违反	是否区分严重程度	覆盖时机
期望累计成本	可以；只限制总体平均	由成本大小决定	通常约束输出策略，训练另查
轨迹事件概率	可以；总概率有上限	事件本身只计真假	须指定回合或整个学习过程
逐步或逐轨迹硬要求	在声明范围内不允许	可另设轨迹预算	只有从训练起执行才覆盖训练

表 8.3　约束的三种判定方式。“不允许”仍以动力学、扰动范围、状态信息和执行机制满足前提为条件，不表示无条件排除现实中的一切事故。

8.4.1 期望累计成本约束下的安全学习

若要求每天的平均危险暴露时间不超过某个值，可以使用**约束马尔可夫决策过程**（constrained Markov decision process, CMDP）：在普通 MDP 上增加成本 $c_i(s,a)$ 与预算 b_i，求解

$$\max_{\pi} J(\pi) \quad \text{满足} \quad J_{c_i}(\pi) := \mathbb{E}_{\pi}\sum_{t\ge 0}\gamma^t c_i(s_t,a_t) \le b_i, \qquad i=1,\dots,m_c. \tag{8.10}$$

奖励衡量要争取的收益，成本约束划出可行策略。若成本来自转移结果，可先用条件期望定义 $c_i(s,a)$，采样时仍记录实际成本。期望约束允许少量轨迹成本很高。例如单步教学任务以 0.99 概率成本 0、以 0.01 概率碰撞并产生成本 10，期望成本只有 0.1；预算 0.1 允许它，但没有禁止碰撞。

有限状态动作、已知转移核且 $0 \le \gamma < 1$ 时，第 2 章的占用度量给出一个精确的凸表示。令 $d(s,a)$ 为归一化折扣占用量，则 CMDP 等价于

$$\begin{aligned} \max_{d\ge 0} \quad & \frac{1}{1-\gamma}\sum_{s,a} d(s,a)R(s,a), \\ \text{满足} \quad & \sum_{a} d(s,a) = (1-\gamma)\rho_0(s) + \gamma\sum_{\bar{s},\bar{a}} d(\bar{s},\bar{a})P(s\mid \bar{s},\bar{a}), \\ & \sum_{s,a} d(s,a)c_i(s,a) \le (1-\gamma)b_i \quad (i=1,\dots,m_c). \end{aligned} \tag{8.11}$$

第一组等式是折扣流守恒；对状态求和可得 $\sum_{s,a} d(s,a) = 1$。成本约束右侧必须乘 $1-\gamma$，因为原预算针对未归一化的累计成本，而不是一次从 d 抽样的平均成本。给定可行占用解，在 $d(s) = \sum_a d(s,a) > 0$ 的状态取 $\pi(a\mid s) = d(s,a)/d(s)$；零占用状态任取合法分布。代入流方程，该策略产生原占用量，因而保留回报与成本。与无约束折扣 MDP 不同，最优策略未必能取确定性。

定理 8.9　约束最优可能需要随机化　单步任务只有一个初始状态，两个动作的回报与成本分别为 $(1,1)$ 和 $(0,0)$，期望成本预算为 $1/2$。确定性可行策略的最优回报为 0；随机策略的最优回报为 $1/2$。

证明　确定性策略只有两个。选择第一个动作时成本为 1，违反预算；选择第二个动作时成本为 0、回报为 0，故确定性可行最优值为 0。任意随机策略由选择第一个动作的概率 $p \in [0,1]$ 完全描述，其期望回报与期望成本都为 p。约束等价于 $p \le 1/2$，所以可行策略的回报至多为 $1/2$。取 $p = 1/2$ 达到这个上界，证明完毕。 ■

随机化解决的是平均预算下的资源分配，不会让每条轨迹的成本都等于 $1/2$。该最优策略仍有一半回合成本为 1；若要求每回合成本不超过 $1/2$，只有第二个动作可行。

模型未知时，可以用轨迹估计回报与成本，并将约束写成拉格朗日目标

$$\mathcal{L}(\theta,\lambda)=J(\pi_\theta)-\sum_i \lambda_i\big(J_{c_i}(\pi_\theta)-b_i\big),\qquad \lambda_i\ge 0. \tag{8.12}$$

策略最大化 $\mathcal{L}$，乘子最小化 $\mathcal{L}$。因为 $\partial\mathcal{L}/\partial\lambda_i=b_i-J_{c_i}$，乘子下降一步得到

$$\lambda_i^{(k+1)}=\Big[\lambda_i^{(k)}+\eta_k\big(\widehat{J}_{c_i}^{(k)}-b_i\big)\Big]_+ .$$

成本超标会增大惩罚，成本低于预算则降低惩罚。以下先假定实际执行的就是可微平稳随机策略 π_θ，环境与初态不依赖参数，且满足第 3 章策略梯度的正则条件。对策略参数求导时，固定当前乘子，使用奖励优势 A_r^π 和各成本优势 $A_{c_i}^\pi$：

$$\begin{aligned}\nabla_\theta\mathcal{L}&=\frac{1}{1-\gamma}\mathbb{E}_{(s,a)\sim d^\pi}\Big[\nabla_\theta\log\pi_\theta(a\mid s)A_\lambda^\pi(s,a)\Big],\\ A_\lambda^\pi(s,a)&=A_r^\pi(s,a)-\sum_i\lambda_i A_{c_i}^\pi(s,a).\end{aligned} \tag{8.13}$$

这里的 $1/(1-\gamma)$ 与占用度量的归一化一致。优化器可以把常数吸收入步长，但不能在报告梯度或成本单位时无声删去。若保护器改写动作，下面算法不能把实际动作直接当作候选策略的采样；须按组合机制重新定义价值、占用和得分，或以请求动作为策略输出、将固定保护通道纳入环境，再推导对应更新。

算法 8.2　带成本评论家的原始–对偶更新

输入： 成本定义与预算 b_i，当前策略，奖励及成本评论家，非负乘子

1: **for** $k=0,\dots,K-1$ **do**
2: 用当前策略 π_θ 采样并直接执行，记录 $(s_t,a_t,r_t,c_{1,t},\dots,s_{t+1})$
3: 以 $r_t+\gamma\widehat{V}_r(s_{t+1})$ 及 $c_{i,t}+\gamma\widehat{V}_{c_i}(s_{t+1})$ 为目标更新各评论家；真正终止处不自举，仅采样时间截断仍保留继续价值
4: 从相同批次构造 $\widehat{A}_r,\widehat{A}_{c_i}$，按式 (8.13) 作策略上升
5: 从初态回合或初态价值估计 $\widehat{J}_{c_i}$，按超标量作乘子投影更新
6: 记录策略、成本界、乘子与保护干预；另用独立验证数据决定能否交付
7: **end for**

算法中的采样分布需要与推导对应。从 ρ_0 启动，并独立抽取 $\mathbb{P}(T=t)=(1-\gamma)\gamma^t$，则 (s_T,a_T) 恰服从 d^π。实际实现也可对有限轨迹加折扣权重；若 $c_i\le c_{i,\max}$，截断到 H 后遗漏的期望成本至多 $\gamma^H c_{i,\max}/(1-\gamma)$。该余项以及评论家误差都应进入约束判断。对于上面的单步例，$\mathcal{L}=p-\lambda(p-1/2)$，

固定 $\lambda < 1$ 时策略倾向增大 p，固定 $\lambda > 1$ 时倾向减小 p；乘子 $\lambda = 1$ 时所有 p 的拉格朗日值相同。仅找到这个乘子并没有选出可行的最优 $p = 1/2$，策略恢复仍是必要步骤。

图 8.6 把两条反馈分开。一次批量更新的交互代价为轨迹总步数，评论家数量随成本数 m_c 增加，反向传播代价取决于网络规模。乘子过快变化可能使策略追逐移动目标，成本稀疏或严重低估可能使惩罚长期不足。离策略数据还需要第 4 章的覆盖与校正条件；保护器改写动作后，不能仍把日志当作未保护策略的同策略样本。

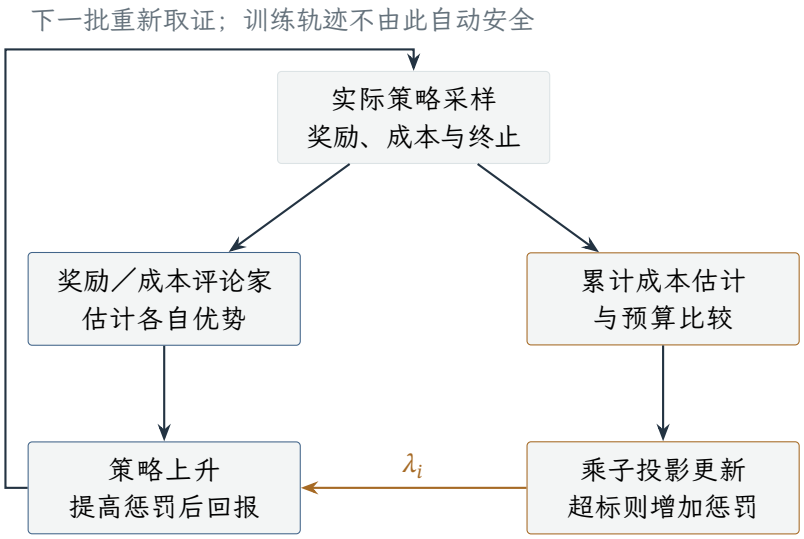


图 8.6　期望成本约束的两条反馈。奖励与成本优势共同推动策略更新，累计成本与预算的差推动乘子更新；这是一种求解循环，不是每次采样均满足约束的证书。

定理 8.10　有限折扣 CMDP 的强对偶　有限状态动作、折扣因子小于 1、奖励与成本有界且至少有一个可行策略时，允许随机平稳策略的 CMDP 与占用度量线性规划等价，且

$$\max_{\pi:\, J_{c_i}(\pi)\le b_i} J(\pi) = \min_{\lambda \ge 0} g(\lambda),$$

$$g(\lambda) = \sum_i \lambda_i b_i + \max_{\pi} \left\{ J(\pi) - \sum_i \lambda_i J_{c_i}(\pi) \right\}.$$

原始最优解和有限维线性规划的对偶最优解存在。

证明思路是把策略换成式 (8.11) 中的占用量。可行占用集是非空有界闭多面体，线性目标有有限最优值；有限维线性规划强对偶给出对偶最优值相等。流守恒的对偶变量是状态价值，成本不等式的对偶变量是非负乘子。先对占用流求最大值、保留成本乘子，便得到上式。互补松弛还要求 $\lambda_i^\star (J_{c_i}(\pi^\star) - b_i) = 0$：严格富余的预算不需要正惩罚，但紧约束也未必有

严格正乘子。这个论证依赖的是占用多面体，不是任意神经网络参数集的凸性；参数化策略可能无法表示最优占用量，交替梯度也可能停在非全局解。

约束策略优化（constrained policy optimization, CPO）选择另一种更新方式：在旧策略附近，用回报和成本的局部代理问题限制一次更新的影响。理解其结论要保留代理误差。令旧策略 π 与候选策略 π' 均为平稳 Markov 策略，对奖励或任一成本 f 定义

$$\mathcal{S}_f(\pi',\pi) = J_f(\pi) + \frac{1}{1-\gamma}\mathbb{E}_{s\sim d^{\pi},a\sim\pi'} A_f^{\pi}(s,a),$$
$$\epsilon_f = \max_s \left|\mathbb{E}_{a\sim\pi'} A_f^{\pi}(s,a)\right|.$$

在共同 MDP、共同初态和有界优势下，有

$$\begin{aligned} J(\pi') &\geq \mathcal{S}_r(\pi',\pi) - \frac{2\gamma\epsilon_r}{(1-\gamma)^2}\overline{D}_{\mathrm{TV}}, \\ J_{c_i}(\pi') &\leq \mathcal{S}_{c_i}(\pi',\pi) + \frac{2\gamma\epsilon_{c_i}}{(1-\gamma)^2}\overline{D}_{\mathrm{TV}}, \\ \overline{D}_{\mathrm{TV}} &= \mathbb{E}_{s\sim d^{\pi}}\frac{1}{2}\sum_a |\pi'(a\mid s)-\pi(a\mid s)|. \end{aligned} \tag{8.14}$$

关键估计是占用变化界 $\|d^{\pi'} - d^{\pi}\|_1 \leq 2\gamma\overline{D}_{\mathrm{TV}}/(1-\gamma)$。性能差恒等式原本在 $d^{\pi'}$ 下平均优势；将其换成 d^{π}，用 ϵ_f 乘上占用差，再除以 $1-\gamma$，就得到上述误差项。若 $\mathbb{E}_{d^{\pi}} D_{\mathrm{KL}}(\pi'\|\pi) \leq \kappa$，Pinsker 不等式和 Jensen 不等式进一步给出 $\overline{D}_{\mathrm{TV}} \leq \sqrt{\kappa/2}$。因此，精确求得 $\mathcal{S}_{c_i}$ 加上误差余量不超过 b_i，才直接推出下一策略成本达标。完整的界与 CPO 构造见原论文[7]。

实际 CPO 用样本优势、成本约束的一阶近似和 KL 的二阶近似求局部步，再以线搜索检查代理量；ϵ_f 的全状态上界通常也并未被精确估计。若只令线性化成本代理不超预算，理论上至多得到仍带余项的成本界，不能抹掉余项而宣称严格可行。Lagrangian PPO 或 SAC 把乘子惩罚接入各自策略目标，继承相应采样与近似误差；SAC 若含熵奖励，还需说明优化的回报已改变。奖励约束策略优化（reward constrained policy optimization, RCPO）使用便于学习的替代惩罚及多时间尺度更新，其收敛依赖替代惩罚与原约束的关系、步长和优化假设，不等于任意换一个奖励后就能满足原成本约束[8]。

至此可以分清四层结论：理想占用规划有全局最优与强对偶；近似更新有求解和估计误差；最终策略需要独立检查原成本；训练轨迹是否安全仍是另一个约束问题。最后一层不会由输出策略的平均成本达标自动获得。

[7] J. Achiam, D. Held, A. Tamar, P. Abbeel, *Constrained Policy Optimization* In Proceedings of the 34th International Conference on Machine Learning, 2017, pp. 22–31

[8] C. Tessler, D. J. Mankowitz, S. Mannor, *Reward Constrained Policy Optimization* In International Conference on Learning Representations, 2019

8.4.2　轨迹事件概率约束下的安全学习

“平均碰撞成本低”有时仍不符合需求，用户可能直接要求每次导航发生任意碰撞的概率不超过 1%。设 E_t 表示动作 t 导致碰撞，定义

$$F_H = \bigcup_{t=0}^{H-1} E_t, \qquad \mathbb{P}_\pi(F_H) \le \varepsilon.$$

这称为**机会约束**（chance constraint），即允许违约发生，但把指定事件的概率限制在阈值内。时域 H 是定义的一部分。$\mathbf{1}\{F_H\}$ 不区分一次或多次碰撞，也不区分损坏 1 个或 100 个部件；相同的事件概率可以对应完全不同的事故成本。

要精确计算首次碰撞概率，可把“是否已经失败”加入状态。令 $z_0 = 0$，$z_t \in \{0,1\}$，并递推 $z_{t+1} = z_t \vee \mathbf{1}\{E_t\}$。若原系统和碰撞判定在状态、动作与后继状态上是马尔可夫的，则 (s_t, z_t) 也是马尔可夫状态，且 $\mathbb{P}_\pi(F_H) = \mathbb{E}_\pi z_H$。对于以状态集合 $\mathcal{B}$ 表示的危险区域，也可令 $z_0 = \mathbf{1}\{s_0 \in \mathcal{B}\}$，将初始失败纳入事件；两种起始约定不能混用。

固定时间相关策略 π_t 后，概率价值 $v_t(s,z)$ 满足

$$\begin{aligned} v_H(s,z) &= z, \\ v_t(s,z) &= \sum_{a} \pi_t(a \mid s, z) \sum_{s'} P(s' \mid s, a)\, v_{t+1}\big(s', z \vee e(s,a,s')\big), \end{aligned} \tag{8.15}$$

其中 $e(s,a,s')$ 是本步事件指示量。递推从终端标记开始，按 $t = H-1, \dots, 0$ 计算，最后对 ρ_0 平均 $v_0(s,0)$。这是概率的普通期望递推，不应额外乘奖励任务中的折扣因子。也可把首次失败成本定义为 $k_t = \mathbf{1}\{z_t = 0, z_{t+1} = 1\}$，则 $\sum_t k_t = z_H$；普通碰撞次数之和一般不等于 z_H。

定理 8.11　风险预算的并集界　对任意有限个事件 $E_0, \dots, E_{H-1}$，无须独立性，都有

$$\mathbb{P}\left(\bigcup_{t=0}^{H-1} E_t\right) \le \sum_{t=0}^{H-1} \mathbb{P}(E_t).$$

因而若 $\mathbb{P}(E_t) \le \varepsilon_t$ 且 $\sum_t \varepsilon_t \le \varepsilon$，则整回合失败概率不超过 ε。

证明　固定任意样本结果 ω。若没有事件发生，并集指示量与各事件指示量之和都是 0；若至少一个事件发生，并集指示量为 1，而指示量之和至少为 1。因此逐样本有

$$\mathbf{1}\left\{\omega \in \bigcup_t E_t\right\} \le \sum_t \mathbf{1}\{\omega \in E_t\}.$$

两边取期望，并对有限和使用期望线性性，即得到第一式。逐项代入 $\mathbb{P}(E_t)\le \varepsilon_t$，再使用预算和条件，得到第二个结论。整个推导没有使用事件独立性。 ■

并集界重复计算了同一轨迹上的多次事件，因此可能保守。另一种常用预算针对存活条件。令 $S_t=\bigcap_{j<t}E_j^{c}$，在 $\mathbb{P}(S_t)>0$ 时定义 $q_t=\mathbb{P}(E_t\mid S_t)$，则由条件概率乘法

$$\mathbb{P}(F_H)=1-\mathbb{P}(S_H)=1-\prod_{t=0}^{H-1}(1-q_t).$$

取条件预算 $\beta_t\in[0,1]$，则 $q_t\le\beta_t$ 推出 $\mathbb{P}(F_H)\le 1-\prod_t(1-\beta_t)\le\sum_t\beta_t$。这里的 q_t 已经对存活历史求了平均；若要求每个存活历史下的条件概率都不超过 β_t，这是更强的充分条件。若某时刻存活概率为 0，整回合失败概率已经是 1，不再需要定义后续条件概率。不能将无条件 $\mathbb{P}(E_t)$、存活条件 q_t 和特定状态下的概率混作同一预算。

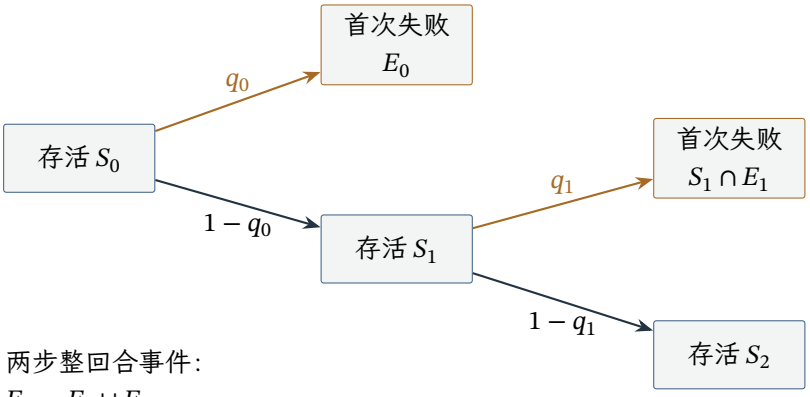
教学计算中，若每步给定存活后的碰撞概率都是 0.01，则 $H=10$ 时整回合概率为 $1-0.99^{10}\approx 0.0956$，$H=100$ 时为 $1-0.99^{100}\approx 0.6340$。这两个数不需要额外假设各 E_t 独立，因为条件概率已被直接给定。若要求 100 步整回合不超过 0.01，并且均匀分配条件预算，每步应满足 $\beta\le 1-0.99^{1/100}\approx 0.00010050$。图 8.7 另将多个训练回合括在一起：最终策略单回合的 F_H 与训练期间任一回合出事的事件，具有不同样本空间和时域。

如何学习带事件约束的策略，取决于可得信息。直接采样时，每回合记录一次 z_H，用其均值估计概率，并用轨迹得分 $z_H\sum_t\nabla\log\pi(a_t\mid h_t)$ 估计概率梯度；再把它作为拉格朗日约束更新。这种估计在稀有事件下方差大，零观测不是零梯度背后的安全证明。已知模型时，可用式 (8.15) 评价候选策略，或在时间与失败标记增广状态上优化期望终端成本，单次稠密评价代价为 $O(H|\mathcal{S}|^2|\mathcal{A}|)$。两种方法都必须保证事件标记完整，不能将超时截断后没有记录的事故当作没有发生。

剩余风险预算还可作为决策状态。到达尚未失败的 (t,s) 且剩余允许概率为 b 时，对候选动作 a 记本步立即失败概率为 $p_f(s,a)$，给各个未失败后继状态分配预算 $b(s')$，要求

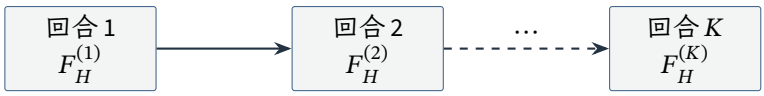
$$p_f(s,a)+\sum_{s'\,:\,e(s,a,s')=0}P(s'\mid s,a)b(s')\le b. \tag{8.16}$$

然后选择满足这个条件且未来回报最高的动作与预算分配，到达 s' 后携带 $b(s')$ 继续。最后一步后剩余失败概率为 0，由向后归纳可知这个约束确实控制整个后续失败概率。随机化动作时，对动作也取平均，并保留选定



两步整回合事件：
$F_2 = E_0 \cup E_1$
概率 $1-(1-q_0)(1-q_1)$

训练期另对多个回合取并集：



$F_{\text{训}} = \bigcup_{k=1}^{K} F_H^{(k)}$，策略可能随训练改变

图 8.7　单步事件、整回合事件与整个学习过程事件。树在首次失败后合并成终止分支；下方回合可以使用不同策略，不能直接套用固定策略独立同分布的频率模型。

分支的预算。连续预算增加一个状态维度，网格化会带来规模和近似误差；不能只从 b 中减去一个未定义的“风险分数”。

CVaR 有时可以构造机会约束的保守替代，但必须先定义违约量。令 $X(\tau) > 0$ 恰好表示失败，例如轨迹上最大的边界超出量。若 X 可积，要求

$$\mathrm{CVaR}_{1-\varepsilon}(X) \le 0 \quad \Longrightarrow \quad \mathrm{VaR}_{1-\varepsilon}(X) \le 0 \quad \Longrightarrow \quad \mathbb{P}(X > 0) \le \varepsilon.$$

第一个箭头用尾部均值不小于分位点，第二个用分位点定义。反向一般不成立：以 0.99 概率取 $X = -1$、以 0.01 概率取 $X = 100$，满足 $\varepsilon = 0.05$ 的机会约束，但最差 5% 的均值为 $(0.01 \times 100 - 0.04)/0.05 = 19.2 > 0$。若直接令 $X = \mathbf{1}\{F_H\}$，则 $\mathrm{CVaR}_{1-\varepsilon}(X) = \min(1, p/\varepsilon)$；把这个非负量限制为 0 会要求 $p = 0$，远比原机会约束严格。替代目标的含义取决于损失编码，而非 CVaR 名称本身。

表 8.4 对齐这些方法的信息需求。直接采样依赖完整回合，概率递推和预算分配依赖可信模型，CVaR 替代还引入尾部严重程度；选择方法前应明确手头具备哪一种信息。

方法	必要信息与记录	计算及主要边界
整回合采样	完整事件标记、固定时域与初态协议	每回合一个 Bernoulli 量；罕见事件样本少
概率价值递推	转移模型、时间、已失败标记	逐阶段备份；模型漏掉危险转移即失效
风险预算分配	上述模型、剩余预算及后继分配	增广预算空间；可行分配未必存在
CVaR 替代	可积违约量及其尾部分布	同时限制尾部严重程度；通常更保守

表 8.4　机会约束的四种处理方式。它们分别解决估计、规划或保守替代问题，不能用相同数值阈值互相替换。

若学习过程有 K 回合，记第 k 回合失败事件为 $F_H^{(k)}$，训练期事件是 $F_{\text{训}} = \bigcup_{k=1}^{K} F_H^{(k)}$。即使每个训练回合都有概率上界 ε_k，也只能直接得到 $\mathbb{P}(F_{\text{训}}) \le \sum_k \varepsilon_k$；自适应训练中可先对过去训练历史给条件上界，再用全期望与并集界。仅验证训练结束后的策略，完全没有约束先前探索使用的策略序列。

8.4.3 逐步与逐轨迹硬要求下的安全学习

假如导航机器人的位置仍在允许区域内，但已经高速接近边界，且剩余制动力不足，那么“当前位置合法”没有留下下一步的可行选择。硬安全要求需要关注可持续保持的状态，而非只检查即时越界。对已知离散系统

$\boldsymbol{x}_{t+1} = f(\boldsymbol{x}_t, \boldsymbol{u}_t, \boldsymbol{w}_t)$，令 $\mathcal{X}$ 为允许状态集，$\mathcal{U}(\boldsymbol{x})$ 为可执行输入集，$\mathcal{W}(\boldsymbol{x}, \boldsymbol{u})$ 为允许扰动集。

定义 8.12　控制不变集与可恢复集　集合 $\mathcal{K} \subseteq \mathcal{X}$ 是鲁棒控制不变的，如果每个 $\boldsymbol{x} \in \mathcal{K}$ 都有输入 $\boldsymbol{u} \in \mathcal{U}(\boldsymbol{x})$，使所有 $\boldsymbol{w} \in \mathcal{W}(\boldsymbol{x}, \boldsymbol{u})$ 对应的后继状态仍在 $\mathcal{K}$。一个从 $\mathcal{K}$ 内选择这类输入的规则称为备份策略。给定备份不变集和步数 N，可恢复集由那些存在控制策略、能在所有允许扰动下始终留在 $\mathcal{X}$ 并于至多 N 步进入 $\mathcal{K}$ 的状态组成。

允许状态集未必不变，可恢复集也依赖输入限幅、扰动和可用时间。若要求整条轨迹成本不超过 B，还应保留剩余预算 $b_{t+1} = b_t - c_t$、$b_0 = B$，并在增广状态 $(\boldsymbol{x}_t, b_t)$ 上要求 $b_t \geq 0$ 及未来可行。折扣预算对应扣减 $\gamma^t c_t$，或采用一致的相对时刻预算递推；不能用期望成本评论家替代每条轨迹的余额。

定理 8.13　安全集的一步封闭性保证　假定动力学 f 已知，实际状态可准确获得，初态 $\boldsymbol{x}_0 \in \mathcal{K}$，实际扰动始终在声明集合内。若每个 $\boldsymbol{x} \in \mathcal{K}$ 的可行保护输入集合

$$\mathcal{U}_{\mathcal{K}}(\boldsymbol{x}) = \{\boldsymbol{u} \in \mathcal{U}(\boldsymbol{x}) : f(\boldsymbol{x}, \boldsymbol{u}, \boldsymbol{w}) \in \mathcal{K}, \ \text{对所有} \boldsymbol{w} \in \mathcal{W}(\boldsymbol{x}, \boldsymbol{u})\}$$

非空，且执行器在每步实际施加其中一个输入，则每条允许扰动轨迹都满足 $\boldsymbol{x}_t \in \mathcal{K}$，$t \geq 0$。

证明　固定任意满足扰动集合限制的轨迹。初始条件给出 $\boldsymbol{x}_0 \in \mathcal{K}$，这是归纳起点。假设在某个 t 有 $\boldsymbol{x}_t \in \mathcal{K}$。集合非空保证能够选择 $\boldsymbol{u}_t \in \mathcal{U}_{\mathcal{K}}(\boldsymbol{x}_t)$；按定义，对所有允许扰动，特别是实际发生的 $\boldsymbol{w}_t$，

$$\boldsymbol{x}_{t+1} = f(\boldsymbol{x}_t, \boldsymbol{u}_t, \boldsymbol{w}_t) \in \mathcal{K}.$$

归纳步成立，故所有有限 t 都有 $\boldsymbol{x}_t \in \mathcal{K}$。由于起初固定的轨迹任意，结论对每条允许扰动轨迹均成立。 ■

证明的力量来自全称条件，也因此对前提敏感。如果 $\mathcal{U}_{\mathcal{K}}$ 为空，保护器就没有满足要求的输入；如果用错误状态作判断，执行动作可能不在真实状态的可行集合中；如果扰动越界或动作延迟未建模，一步封闭性也不再适用。状态只能估计为集合 $\widehat{\mathcal{X}}_t$ 时，应要求同一个输入对其中所有可能真实状态和所有允许扰动都有效，且另行保证真实状态确在估计集合内。

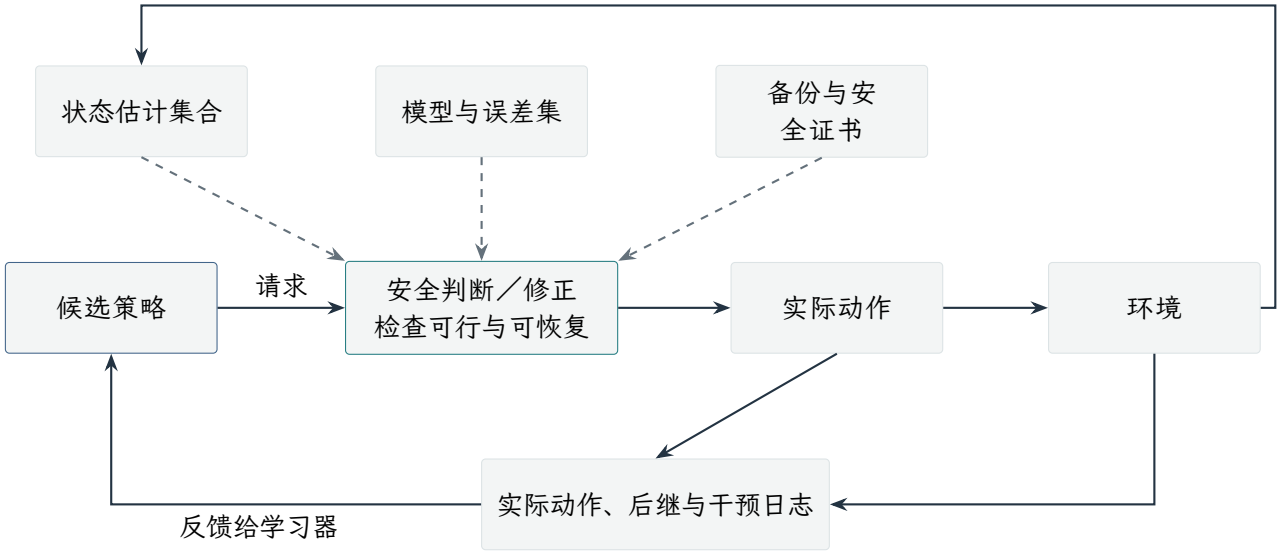


图 8.8 保护器改变的是实际执行链路。实线是决策与日志流，虚线是保护判断所依赖的模型和证书；评估时必须说明保护是否启用、哪些动作被替换，以及保证针对哪个组合系统。

定理 8.13 给出了可以用于执行检查的条件：已验证的不变集 $\mathcal{K}$，以及使所有允许后继仍落在 $\mathcal{K}$ 内的一步保持条件。本节将这类数学条件及其成立依据称为**安全证书**（safety certificate）。在下面的算法中，证书具体指上述不变集与保持条件；后文的屏障函数和预测过滤器提供构造或检验相应条件的其他方式。

算法 8.3 带可行性检查的安全过滤

输入： 候选策略、有效状态估计集合、动力学及误差集合、已验证不变集 $\mathcal{K}$ 及其一步保持条件、可用备份

1: **for** 每个执行时刻 t **do**
2: 取得候选动作 $\boldsymbol{u}_t^{\text{候}}$，更新状态估计集合
3: 按定理 8.13 构造保护输入集合：同一输入须使所有可能真实状态在所有允许扰动下的后继都留在 $\mathcal{K}$
4: 若候选动作在集合中，直接使用；否则求与候选动作距离最小的可行输入
5: 若优化超时，使用已验证且当前仍有效的备份；若连备份也不可行，报告保证失效并触发预设应急机制
6: 执行实际动作，记录候选、实际动作、干预原因和后继状态，反馈给学习器
7: **end for**

应急停止可以是工程措施，但只有也满足模型与可行性条件时才是证明中的安全输入。“优化失败就刹车”不能补上一个本来已无路可退的状态。图 8.8 因此让模型、估计与备份直接输入保护模块，并将实际动作反馈给学习器。

离散动作系统可以直接屏蔽不满足一步保持条件的动作，再在剩余动作中按候选策略选择。屏蔽所需的状态可能还包含任务自动机或历史标记；只过滤“向墙内移动”等即时非法动作的普通 action masking，并没有证明未来安全。基于安全规格构造的屏蔽则在抽象模型上维护允许的后继行为，其保证仍取决于抽象是否覆盖真实系统[9]。

连续输入下，若可行集可计算，可以求投影

$$\min_{\boldsymbol{u}\in\mathcal{U}_{\mathcal{K}}(\boldsymbol{x})} \|\boldsymbol{u}-\boldsymbol{u}^{\text{候}}\|^2.$$

教学系统 $x_{t+1}=x_t+u_t+w_t$ 取 $\mathcal{K}=[0,1]$、$u_t\in[-0.2,0.2]$、$w_t\in[-0.05,0.05]$。鲁棒一步条件为 $0.05-x_t\le u_t\le 0.95-x_t$。在 $x_t=0.96$ 时，候选 $u_t=0.1$ 会使最坏后继达到 1.11；与输入限幅取交后，可行集为 $[-0.2,-0.01]$，投影得到 $u_t=-0.01$，后继范围为 $[0.90,1.00]$。这不是“稍微减小动作”便有效，而是显式计算了误差下的全部后继。

控制屏障函数（control barrier function, CBF）把集合写成 $h(\boldsymbol{x})\ge 0$，再限制控制输入使系统不穿出边界。离散时间需要检查 $h(f(\boldsymbol{x},\boldsymbol{u},\boldsymbol{w}))\ge 0$ 对允许扰动成立，或者使用能够推出这一条件的更强不等式。连续时间控制仿射系统 $\dot{\boldsymbol{x}}=\boldsymbol{f}(\boldsymbol{x})+\boldsymbol{g}(\boldsymbol{x})\boldsymbol{u}$ 则常使用

$$\nabla h(\boldsymbol{x})^{\top}\big(\boldsymbol{f}(\boldsymbol{x})+\boldsymbol{g}(\boldsymbol{x})\boldsymbol{u}\big)\ge -\alpha_h(h(\boldsymbol{x})).$$

其中 h 连续可微，α_h 是适当的扩展类 $\mathcal{K}$ 函数，即连续、严格递增且 $\alpha_h(0)=0$。在边界处 $\nabla h\neq 0$、闭环解于声明时域内存在且唯一、输入约束下屏障不等式始终可行、实际执行满足该不等式的反馈且初态在集合内等条件下，比较原理支持前向不变性。控制仿射性使输入在线性不等式中出现，常可与二次投影目标组成二次规划（QP）；输入饱和或多个约束冲突仍会使 QP 不可行。连续时间结论不能直接覆盖采样间隔、执行延迟和模型误差，必须加入相应余量或另作离散分析[10]。

预测安全过滤器（predictive safety filter）进一步检查未来一段控制计划：从当前状态出发，在预测时域内让状态和输入都满足约束，并在末端到达已有备份能维持的不变集[11]。鲁棒版本应使用反馈计划或误差管束，使约束覆盖所有允许扰动，而不是仅让标称轨迹避障。优化目标仍可优先保留候选动作。若上一时刻的可行管束在执行一步后仍包含真实状态，下一时刻可以将旧计划向前平移，并在末端接上备份控制；这是递归可行性的核心理由。模型误差集合突然扩大、终端集失效、状态估计不再被管束覆盖或求解未按时完成，都会破坏这条理由。预测步数、状态维度与非线性误差传播决定在线求解代价，不能仅凭“MPC 过滤”这一名称声称安全。

[9] M. Alshiekh, R. Bloem, R. Ehlers, B. Könighofer, S. Niekum, U. Topcu, *Safe Reinforcement Learning via Shielding* In Proceedings of the AAAI Conference on Artificial Intelligence, 2018

[10] A. D. Ames, X. Xu, J. W. Grizzle, P. Tabuada, *Control Barrier Function Based Quadratic Programs for Safety Critical Systems* In IEEE Transactions on Automatic Control, 2017, vol. 62, no. 8, pp. 3861–3876

[11] K. P. Wabersich, M. N. Zeilinger, *A Predictive Safety Filter for Learning-Based Control of Constrained Nonlinear Dynamical Systems* In Automatica, 2021, vol. 129, 109597

恢复控制关注把系统带回已验证区域，并在恢复过程中保持约束；停止当前学习任务而返回安全种子，也可以是整体方案的一部分。近期的安全复位研究把到达复位区域与避开危险联合建模。无人干预学习还要解决回合之间如何安全重置，而不只保护单回合动作。这是对保证时域的扩展，不表示复位过程天然安全或没有代价[12]。

模型未知时，需要一块已知可安全运行的种子区域或备份控制，再用受保护的数据逐渐缩小误差集、扩展可验证区域。高斯过程（Gaussian process, GP）模型可以提供预测均值与不确定区间，但有用的证书要求：在所声明的状态输入范围与所有取证时刻上，真实动力学以至少 $1-\delta$ 的概率同时落在模型集合内。得到这种联合覆盖通常需要函数正则性、噪声假设、合适的置信参数及对自适应采样的控制。稳定性证书与 GP 误差界相结合的安全学习依赖这些前提，而非只依赖模型给出了方差[13]。

记联合模型覆盖事件为 $\mathcal{E}$。准确的表述是：“在 $\mathcal{E}$ 上，过滤器按不变性条件保持安全；取证程序满足 $\mathbb{P}(\mathcal{E}) \geq 1-\delta$。”单个测试点的 95% 预测区间不能替代整个闭环轨迹上的联合事件。若实际扰动具有无界支持，也不能无条件假设所有时刻均在一个有界集合内；有限时域高概率覆盖与无限时域逐轨迹保证必须分开。

多个机器人共享狭窄通道时，每个机器人在“对方会等待”的假设下都可能有可行计划，两个计划同时执行却相撞。因此还需检查联合输入约束、通信延迟及其他参与者是否遵守建模承诺。去中心化过滤器只有在局部假设彼此相容、联合可行域非空且执行信息满足证明条件时，才可能推出团队安全；不能从个体 QP 各有一个解直接得到联合保证。参与者的响应模型仍由第 7 章提供。

8.5 可靠性评价与保证

一个策略可能在训练目标上满足要求，却没有足够证据支持部署声明；一个受保护系统也可能长期没有事故，却无法说明移除保护后的策略如何表现。评价需要从预设要求出发，明确取得什么证据，再判断这些证据对哪个对象有效。图 8.9 给出本节的过程：运行条件变化时，应重新检查协议与取证，而非只继续累计旧成功次数。

8.5.1 确定验证协议并取得证据

同一策略从不同位置启动，考察的是固定策略的运行分布；同一算法换随机种子重新训练，考察的是算法输出的变化；同一系统换摩擦条件，则考察运行范围。把这三种试验的回合混在一个成功率里，会把策略差异、初态差异和环境变化相互掩盖。

[12] A. Begzadic, N. Shinde, S. Tonkens, D. Hirsch, K. Ugalde, M. Yip, J. Cortes, S. Herbert, *Back to Base: Towards Hands-Off Learning via Safe Resets with Reach-Avoid Safety Filters* In Proceedings of the 7th Annual Learning for Dynamics & Control Conference, 2025, pp. 1154–1166

[13] F. Berkenkamp, M. Turchetta, A. P. Schoellig, A. Krause, *Safe Model-Based Reinforcement Learning with Stability Guarantees* In Advances in Neural Information Processing Systems, 2017

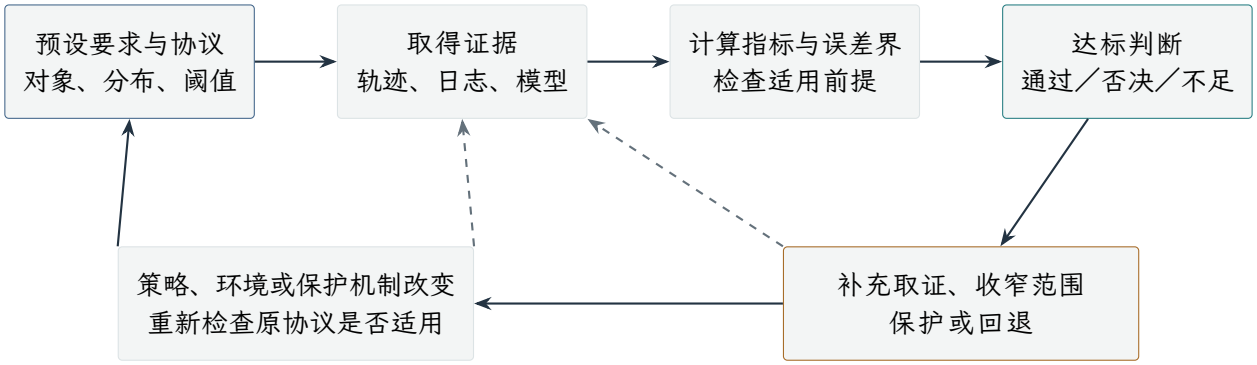


图 8.9 可靠性验证的信息依赖。判断可以触发补充取证、收窄范围、保护或回退；条件改变则要求重新核对协议。流程本身不替代任何统计覆盖或模型证明。

证据来源	统计单位与可控条件	可支持结论	关键缺口
重复训练	一次完整训练；算法、预算、种子分布固定	输出策略指标分布、训练失败概率	不能只挑最好种子报告
固定策略重复运行	一回合；策略和运行协议冻结	协议分布下的回报、成本和事件概率	回合独立性、有效样本量
压力测试	指定极端场景或攻击；权限固定	已测条件下的失效及响应	不直接给常态运行失败频率
已有日志	日志中的回合；行为机制可追溯	覆盖与校正条件下的离线评价	漏报事件、选择性记录、支持不足
形式化模型分析	模型中的状态、轨迹或扰动集合	前提成立时的全称性质	真实系统是否满足抽象与误差前提

表 8.5 取证方式与保证对象的对应关系。重复训练的一条学习曲线不是一次固定策略运行，主动挑选的极端情况也不是从日常运行分布随机抽到的回合。

一份可执行的协议至少应固定：交付策略和保护器版本、统计单位、初态与环境抽样分布、时域和终止规则、允许的扰动与参与者、样本预算、失败判定、回报与成本阈值、置信要求。假如碰撞意味着“机身越过边界”，就不能仅记录控制器是否发出报警。恢复时间要约定从何时起算、恢复到哪个集合；到时仍未恢复的轨迹应按删失或超时规则处理，不能从平均值中直接删除。

表 8.5 按证据来源指出可以支持的结论。模型证明与运行试验可以互补：前者覆盖显式模型中的全部允许情况，后者检查实际系统是否出现模型遗漏；二者的保证范围都需要写明。

验证信息应留出。用于更新策略的任务、攻击和训练种子，不再是对同一策略完全未使用的测试证据；若根据验证集反复挑选策略，选择过程也利用了该集。可将开发、策略选择与最终验收分开，或事先使用对整个候选类同时有效的界。随机种子留出还不够：如果同一个困难地形被反复用于调整保护阈值，地形信息仍已进入选择过程。

每个回合应保留初始条件、请求动作、执行动作、奖励、损失、成本、事件标记、接管时刻和恢复时间。事件后的数据可能更有诊断价值，不能因回合“已经失败”而在日志中消失。干预率也应说明分母：被替换动作数占总执行动作数，与发生过至少一次接管的回合比例，是不同指标。

稀有事件需要增加有效取证，而不是复制已有成功轨迹。若通过重要性采样提高危险场景出现频率，须知道目标运行分布相对于采样分布的密度比，保证目标支持被覆盖，再对完整事件统计加权；未知密度比的主动压力测试只提供场景证据。相关回合、同一条长轨迹切出的重叠窗口，以及共享未重置环境状态的连续试验，都不自动构成独立样本。

8.5.2 由证据估计指标与保证范围

冻结策略后，一条完整轨迹给出 $G_j, L_j, C_{i,j}$ 和失败标记 $Y_j = \mathbf{1}\{F_H^{(j)}\}$。样本均值估计回报与成本，$\widehat{p} = n^{-1}\sum_j Y_j$ 估计失败概率；经验分位数和式 (8.2) 的样本目标估计尾部损失。尾部只使用少量有效质量，不能拿回报均值的标准误直接当作 CVaR 的误差。恢复时间还需要处理未在观察时域内恢复的回合。

点估计给出一个数；置信界限制统计程序的覆盖错误率；模型误差界限制近似模型与真实系统的偏差；形式化性质则是前提下的逻辑结论。它们回答不同问题。轨迹内的状态高度相关，并不妨碍独立回合之间的 Bernoulli 分析，但若把每一步当作独立回合，就改变了有效样本量与事件定义。

定理 8.14　零失败记录的单侧上界　对预先固定的策略、运行分布、事件和正整数样本量 n，假设 n 个回合的失败标记独立同分布为 Bernoulli(p)。取 $0 < \delta < 1$，若观察到零次失败，则精确二项单侧置信上界为

$$U_0(n, \delta) = 1 - \delta^{1/n}.$$

这不是对 $p = 0$ 的证明，也不覆盖根据数据选择样本量或策略的未经校正程序。

证明　令 $K = \sum_{j=1}^{n} Y_j$。独立性给出 $\mathbb{P}_p(K = 0) = (1-p)^n$。要检验一个候选概率 p_0 是否过大，零失败提供的单侧尾概率就是 $(1-p_0)^n$。边界方程 $(1-p_0)^n = \delta$ 的解为 $p_0 = 1 - \delta^{1/n}$；更大的 p_0 产生零失败的概率小于 δ，因而在该单侧检验中被拒绝。

为明确置信覆盖的含义，可先构造一个保守的完整程序：$K = 0$ 时返回上界 U_0，$K > 0$ 时返回 1。若真实 $p \le U_0$，它从不漏盖；若

> $p > U_0$，漏盖只能发生在 $K = 0$，概率为 $(1-p)^n < \delta$。因此程序的覆盖率至少为 $1-\delta$。通常的精确二项上界在 $K > 0$ 时也反演相应二项尾概率，得到更紧的数值；在本命题的零失败情形，仍为上述同一表达式。 ■

取 $\delta = 0.05$，100 次零失败的 95% 单侧上界约为 0.029513，即 2.95%，不是 1%。若想仅凭零失败把上界压到 ε 以下，需要事先选择

$$n \geq \left\lceil \frac{\log \delta}{\log(1-\varepsilon)} \right\rceil .$$

因此，1% 阈值至少需要 299 次，0.1% 阈值至少需要 2995 次。表 8.6 全由公式计算，不是机器人实验结果。已经观察到大量成功，仍可能没有积累足够证据排除稀有失败。

固定样本量 n	95% 失败概率上界	与阈值比较
100	0.02951305	尚不能支持 $p \leq 0.01$
299	0.00996915	支持 $p \leq 0.01$
1000	0.00299125	尚不能支持 $p \leq 0.001$
2995	0.00099974	支持 $p \leq 0.001$

表 8.6 零失败的解析教学上界。每行分别代表预先固定样本量的独立验证，不代表持续查看同一次试验并在达标时停止的程序。

离线评价还要追问日志能否识别目标策略的风险。复用第 4 章的轨迹重要性采样，若行为策略 μ 已知且覆盖目标策略 π，同一环境与初态下 $W_j^{\pi} = \prod_{t=0}^{H-1} \pi(a_{j,t} \mid h_{j,t}) / \mu(a_{j,t} \mid h_{j,t})$，就有 $\mathbb{E}_{\mu}[W^{\pi} G] = J_H(\pi)$ 及 $\mathbb{E}_{\mu}[W^{\pi} C_i] = J_{c_i,H}(\pi)$。失败事件也可用 $W^{\pi} Y$ 估计。动作覆盖不等于日志完整：若碰撞之后的记录被删掉，密度比无法恢复根本没有记录的结果。隐藏混杂、执行通道改变或目标动作无支持，则可能使安全指标不可识别。

可以具体写出同时检验性能和安全所需的两个方向。设固定候选 π 和固定基线 π_b 共用 n 条独立同分布的行为回合，且两者的轨迹分布都相对于行为分布绝对连续；只覆盖候选而不覆盖基线，还不足以评价二者之差。定义 $Z_j = (W_j^{\pi} - W_j^{\pi_b}) G_j$ 与 $X_{i,j} = W_j^{\pi} C_{i,j}$。若已知 $Z_j \in [z_-, z_+]$、$X_{i,j} \in [0, x_{i,+}]$ 几乎处处成立，则 Hoeffding 不等式给出

$$J_H(\pi) - J_H(\pi_b) \geq \overline{Z} - (z_+ - z_-) \sqrt{\frac{\log(1/\delta_r)}{2n}} =: \mathrm{LCB}_{\Delta J},$$

$$J_{c_i,H}(\pi) \leq \overline{X}_i + x_{i,+} \sqrt{\frac{\log(1/\delta_i)}{2n}} =: \mathrm{UCB}_{c_i}. \tag{8.17}$$

证明思路是先由换测度恒等式得到 $\mathbb{E}Z$ 为回报差、$\mathbb{E}X_i$ 为候选成本，再分别对有界独立样本施加单侧浓缩不等式。用并集界，所有声明同时成立的

指标或性质	估计／验证方法	覆盖条件	主要误差来源	保证对象
平均回报、成本	回合均值、离线校正与单侧界	固定策略和协议；独立或已处理相关性	抽样、截断、权重与模型偏差	指定策略的期望值
尾部损失、动态风险	累计损失的分位及 CVaR 估计；嵌套目标另需逐阶段条件估计	损失与尾部样本假设；动态目标还需条件分布覆盖	稀有样本、阈值估计、选择及递推误差	事先声明的累计或动态风险
失败概率	完整事件频率、二项或加权界	事件、时域、运行分布明确	漏报、相关回合、分布改变	固定执行系统的回合事件
恢复时间	完整或删失数据分析	恢复集合、起止和删失规则固定	超时删除、选择性接管	指定恢复机制
不变性	模型、误差集、可行性证明	真实闭环满足全部模型前提	状态估计、未建模执行与越界扰动	证书覆盖的保护系统

表 8.7 不同指标需要不同的误差控制。一个回报评论家准确，并不意味着碰撞概率或尾部损失已被准确估计。

概率至少为 $1-\delta_r-\sum_i \delta_i$，无须各估计量相互独立。检验 $\mathrm{LCB}_{\Delta J} \geq -\epsilon_{\text{改进}}$ 与 $\mathrm{UCB}_{c_i} \leq b_i$，才分别支持“不比基线差太多”和“成本达标”。折扣无限时域评价还要补上截断余项。

这里最强的假设是权重及结果有已知界；长时域的乘积权重可能极大，使区间没有实用信息。权重截断降低方差却引入偏差，须另给偏差界；模型辅助估计也引入模型条件。基线自举的安全策略改进（safe policy improvement with baseline bootstrapping, SPIBB）把数据支持不足区域的行为约束在基线附近，研究在相应数据与模型假设下相对基线的性能改进。这个性能含义上的“safe”不直接等于成本或碰撞概率安全：基线可能不安全，候选也可能以更高风险换取更高回报。需要安全声明时，仍须增加单独的成本或事件上界[14]。

[14] R. Laroche, P. Trichelair, R. Tachet des Combes, *Safe Policy Improvement with Baseline Bootstrapping* In Proceedings of the 36th International Conference on Machine Learning, 2019, pp. 3652–3661

若 π 由同一评价数据挑选，式 (8.17) 的普通固定策略界不能原样使用。可对预先确定的有限候选集分配总错误预算，也可用对策略类一致有效的界，或将最终策略冻结后在独立留出数据上验证。保护器在日志期间替换了动作时，权重分母应反映实际行为机制；若评价对象也是受保护系统，目标分子也要反映组合机制。否则估计的并不是要交付的策略或系统。

表 8.7 将每个指标与它需要的覆盖条件对应起来。回报、尾部、事件与恢复过程可以来自同一份日志，但并不共用一种误差界；不变性证明更需要单独核对真实闭环是否落在证书范围内。

价值、分布和世界模型的校准必须说明在哪个策略诱导分布上检查。训练数据覆盖的常见状态上预测准确，不足以覆盖新策略频繁访问的边界状态；多个模型彼此一致，也可能共同遗漏同一个危险机制，因此集成分歧不自动是置信界。形式化结论则要逐项核对真实动力学、状态估计、保护动作和执行器是否满足证明前提，不能只核对名义控制算法。

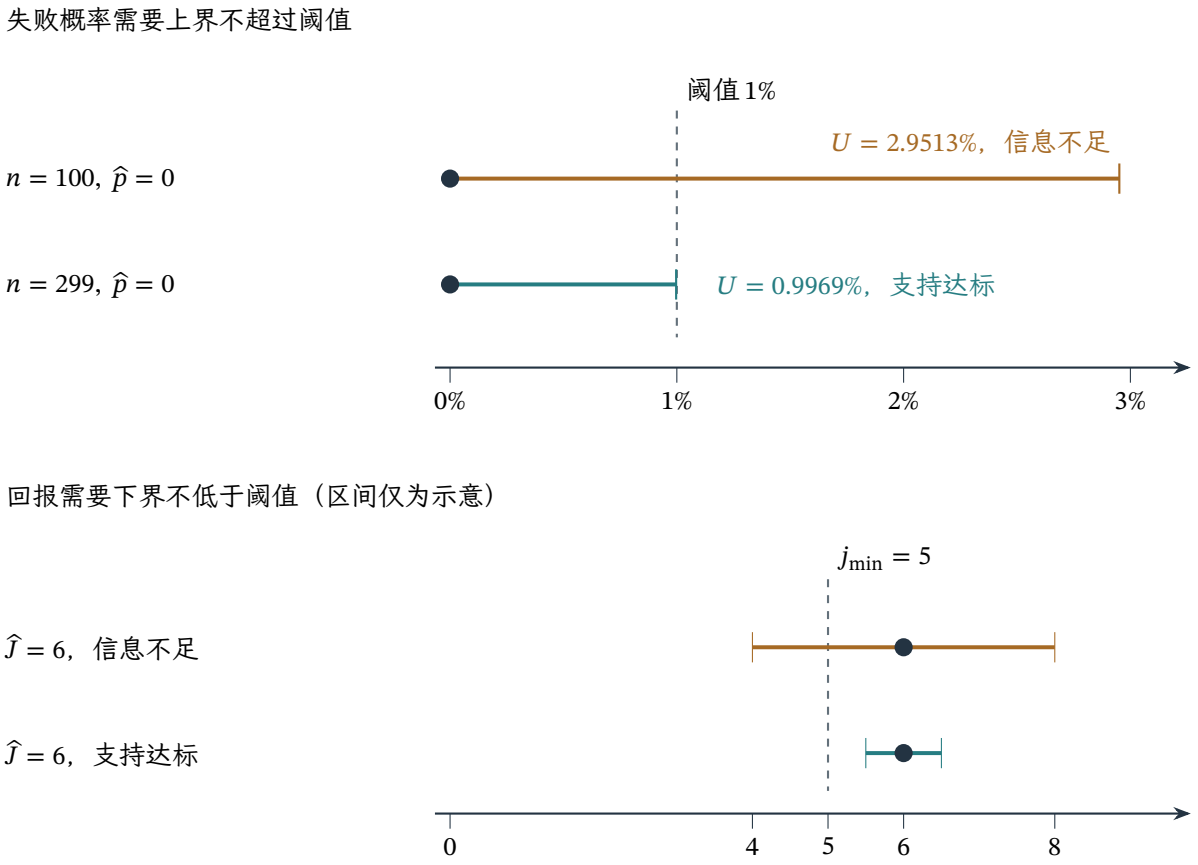


图 8.10 置信界与阈值的方向。上图按 n 次零失败的解析公式计算 95% 单侧上界；下图仅以给定区间示意回报判断，不代表某个统计估计器或实验。点标估计，线段标可支持的指标范围。

8.5.3 依据要求作出判断并持续复核

对于失败概率要求 $p \le \varepsilon$，上置信界 $U_p \le \varepsilon$ 支持达标，下置信界 $L_p > \varepsilon$ 支持不达标；区间跨过阈值时，证据不足以作出这两种结论。对于回报要求 $J \ge j_{\min}$，方向相反：$L_J \ge j_{\min}$ 支持达标，$U_J < j_{\min}$ 支持不达标。多项条件同时要求成立时，要预先控制联合置信错误率，不能给每项各一个 95% 区间后就称整体仍有 95% 覆盖。

图 8.10 上半部分比较两份零失败数据：点估计都为 0，100 次试验的上界仍越过 1%，299 次试验的上界才降到 1% 以下。下半部分用纯示意区间说明回报需要检查下界而非上界；它没有对应未经报告的实验。信息不足时，可以按新的预设方案取得更多证据，或将部署范围收窄到已有覆盖的条件；不能把“不足以确认安全”改写成“已证实不安全”，也不能直接批准原范围部署。

判断还要绑定策略和协议版本。改变摩擦范围会改变轨迹分布，更新策略会改变状态动作占用，升级保护器会改变实际执行行为，增加参与者会改变闭环假设。旧数据不一定全部作废，但需要论证哪些条件仍匹配，哪

些数据需要重加权或补充，哪些模型性质必须重证。只要交付对象或运行范围不再匹配，旧的安全声明就不能原封不动沿用。

运行监测应关注这些前提是否持续成立，例如误差是否越出集合、备份是否仍可行、失败标记是否完整、干预比例是否明显改变。变化可以触发保护、回退、收窄运行范围或补充取证；监测基础设施由系统卷讨论。反复查看固定样本置信区间、直到第一次达标才停止，不自动保留原整体错误率。需要随时有效的判断时，可使用预先分配错误预算的多次检验，或在适当数据假设下使用置信序列，使整个时间序列同时受覆盖控制[15]。

[15] S. R. Howard, A. Ramdas, J. McAuliffe, J. Sekhon, *Time-Uniform, Nonparametric, Nonasymptotic Confidence Sequences* In The Annals of Statistics, 2021, vol. 49, no. 2, pp. 1055–1080

8.6 多种要求的组合与取舍

前面的工具现在可以用于同一个导航决策，但比较时仍要控制变量。以下从基准网格抽象出一个单步路线选项任务：初态固定为起点，动作一次选择整段路线，之后返回到达终点的总用时 T、碰撞标记 I 与成本 $C = 10I$。这是独立的教学模型，不使用基准网格的 0.8 滑移核；$H = 1$、不折扣，回报 $G = -T$，损失 $L = T$。路线内部执行及恢复被汇总为一次结果，时间以教学单位计。

可选策略先限定为四个确定路线选项 A、B、C、D，所有比较使用同一初态和这同一组候选。干燥环境中，A 以 0.95 概率用时 5、以 0.05 概率用时 25，其余三条路线用时固定为 7、8、9。湿滑环境只让 A、B 的总用时各增加 10，C、D 不变。两种环境中，碰撞概率分别为 0.02、0.005、0.003、0；为把时间与安全成本的影响分开，教学模型规定 I 与 T 独立，且碰撞不另外终止路线选项。这里的联合分布由这些假设完全确定，不能把它解释成真实机器人碰撞与恢复之间的经验规律。

表 8.8 由该分布精确计算。例如 A 的平均用时为 $0.95\times5+0.05\times25=6$，0.95 分位水平的 CVaR 为 25，期望成本为 $10\times0.02=0.2$。其余行用相同公式得到。全部路线均未启用外部保护，干预为 0；“无干预”只说明执行机制，不是一个安全指标。

只优化标称平均回报时选择 A；改为最小化标称尾部损失时选择 B；改为最大化干燥与湿滑两环境中的最坏平均回报时选择 C；在原标称平均回报目标上增加期望成本预算 $b = 0.01$ 时，四个确定选项中只有 D 可行。这四次求解分别只改变一类要求，展示其影响，不是一个算法必须依次完成的四个阶段。

策略类也影响答案。若允许在每回合出发前随机选路线，以 0.2 概率选 B、0.8 概率选 D，就有期望成本 $0.2\times0.05=0.01$，平均用时 $0.2\times7+0.8\times9=8.6$，优于确定选择 D 的 9。故上段关于 D 的最优性明确限定在四个确定选项内，与定理 8.9 一致。概率混合不表示单条轨迹变成了一条“平均路线”，也不会消除 B 回合中的碰撞可能。

路线	标称平均回报	标称尾部损失	湿滑平均回报	碰撞概率	期望成本	干预比例	证据强度
A：捷径	−6	25	−16	0.02	0.20	0	教学模型精确值
B：平稳	−7	7	−17	0.005	0.05	0	教学模型精确值
C：抗滑	−8	8	−8	0.003	0.03	0	教学模型精确值
D：保守	−9	9	−9	0	0	0	教学模型精确值

表 8.8 同一候选集合的解析教学比较。尾部损失为 $\mathrm{CVaR}_{0.95}(T)$；碰撞概率和成本在两环境下按假设相同。D 的零概率仅属于该指定模型，所有行均无真实部署统计证据。

若这些要求同时存在，可对声明的模型族 $\mathcal{M}$ 求解，例如

$$\begin{aligned} \min_{\pi\in\Pi} \quad & \sup_{M\in\mathcal{M}} \mathcal{R}_M(L^\pi), \\ \text{满足} \quad & \inf_{M\in\mathcal{M}} J_M(\pi) \geq j_{\min}, \\ & \sup_{M\in\mathcal{M}} J_{c_i,M}(\pi) \leq b_i \quad (i=1,\dots,m_c). \end{aligned} \tag{8.18}$$

这里 $\mathcal{R}_M$ 必须事先选定为静态或动态风险；Π 说明允许历史依赖和随机化的范围。第一个最坏值作用于风险目标，回报下界和成本上界也各自在模型族中取不利方向。只对回报作鲁棒优化，不会自动使成本对环境变化鲁棒；反过来，鲁棒成本达标也不保证平均任务收益足够。

图 8.11 把满足各阈值的策略画成集合，最终可行域是它们与 Π 的交集。要求增多只能保持或缩小可行域，最优值不会因此自动改善。在上述确定路线集合中，若同时要求标称 CVaR 不超过 8、最坏平均用时不超过 9、期望成本不超过 0.01，则没有可行选项：C 满足前两项却成本超标，D 满足后两项却尾部用时为 9。需要扩大策略类、改变环境或重新协商阈值，而不是把求解器返回的最少违反方案当作已满足原要求。

保护贡献应另作控制变量比较。图 8.12 保留基准网格的起终点和障碍，但改成无滑移的确定性教学动力学，并把 $(3,1)$ 标为危险格。关闭保护时，同一候选沿下方五步路径通过危险格；启用保护时，在 $(2,1)$ 处拒绝继续向右，交给已验证的备份返回 $(1,1)$，再沿上方到达终点，共七步。备份在此确定模型中保持位置不进入障碍和危险格；恢复随机滑移后，必须重新检查它是否对所有允许后继仍安全。

右图少了一次危险区域穿越，多了两步行程和一次进入备份控制的切换。这说明受保护系统在该模型上满足的性质，不能归给未保护候选；也不能把路径图中的一步拒绝当成整个回合只有一次动作替换，后续备份动

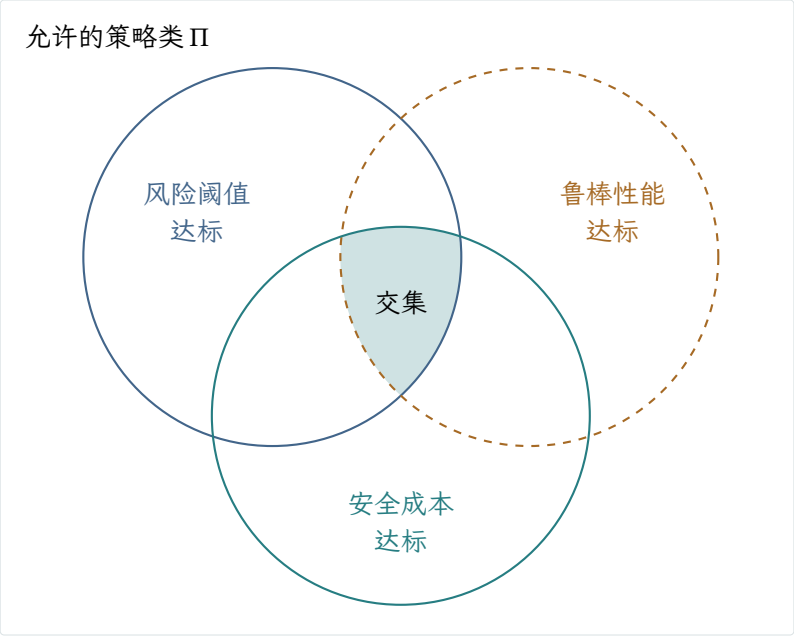


图 8.11　可行策略集合的概念示意，不是教学路线数值的几何嵌入。阴影为三种阈值共同允许的策略；在具体任务中，交集也可能为空。集合边界形状没有凸性含义。

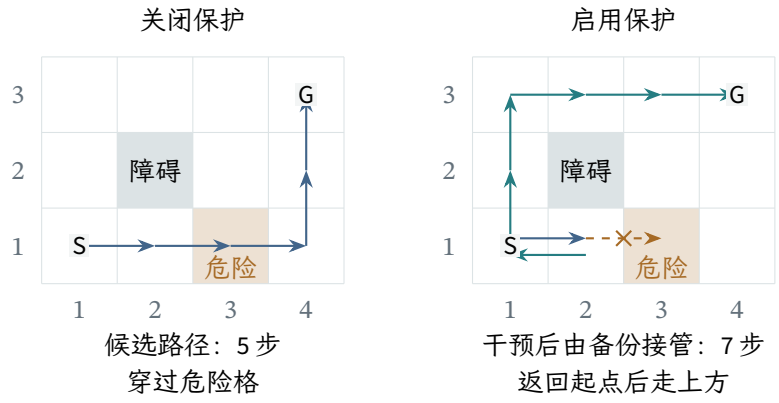


图 8.12　同一候选启用或关闭保护的确定性路径示意，坐标、障碍和起终点沿用基准网格。虚线为被拒绝的请求，实线为实际路径；右图在干预后使用备份，不表示候选策略已自行学会绕行。

要求	决定性条件	方法	相应证据
控制累计尾部	损失、分位水平及事前承诺明确	静态 CVaR 采样更新、状态增广	尾部估计误差与留出轨迹
条件风险一致	条件映射、状态信息与递归目标匹配	嵌套风险 Bellman 更新	算子性质及条件风险估计
覆盖环境变化	扰动位置、信息权限与集合结构明确	鲁棒规划、受扰训练、状态估计	模型覆盖、内层误差与压力测试
平均成本达标	成本单位、初态、折扣及策略类明确	占用规划、原始–对偶与局部约束更新	最终策略的成本上界
事件概率达标	事件、时域、条件预算一致	事件采样、概率递推、预算分配	完整事件记录与有效概率上界
逐轨迹保持安全	误差范围有效、初态可行且保护输入存在	屏蔽、不变集、屏障与预测过滤	真实闭环符合证书全部前提
可靠地作出判断	交付对象、运行协议和取证程序固定	留出验证、联合置信与持续复核	界与阈值比较，并标明信息不足

表 8.9 本章的要求、条件、方法与证据。算法的优化目标与交付时能够成立的保证是两件需要分别检查的事。

作同样需要日志辨认。保护改变了数据分布：学习器看到的安全轨迹可能来自外部修正，继续训练时必须保留候选与实际动作的区别。

探索信息、任务收益、保守性和保护代价因此需要一起衡量。扩大不确定集合提高覆盖范围，却可能降低可达到的收益；更紧的尾部或安全阈值可能增加绕行和接管；更强保护减少危险探索，也可能使某些未执行动作的效果难以识别。合理结论应同时给出行为标准、环境范围、执行机制和证据，不以单一平均分数替代。公平、隐私、解释及目标对齐的共同问题仍由第一卷讨论，本章提供的是把已明确要求接入序贯决策及验证的方式。

8.7 本章小结

平均回报没有说明严重损失的尾部、环境改变后的表现，也没有划定行为可行性。风险准则改变随机结果的比较方式，鲁棒要求改变必须覆盖的环境范围，安全约束改变允许采用的策略集合；三者可以组合，但其目标、信息和证明条件不能互相替换。

风险决策中，静态累计 CVaR 与逐阶段嵌套风险评价不同的对象，状态增广和时间一致性要与目标匹配。鲁棒决策中，扰动作用于动力学、观测还是执行通道，决定可用状态和对手权限；矩形性连接局部最坏备份与全局模型族。安全决策中，期望成本、轨迹事件概率和硬要求允许的违约方式不同，乘子、概率预算和安全过滤分别维护不同性质。

表 8.9 将这些联系收拢为“要求、条件、方法、证据”。阅读任何可信强化学习方法时，都应能回答：它维护什么性质，针对策略还是受保护系统，依赖哪些模型与数据前提，前提改变后原结论还剩多少。

数据支持不足或隐藏风险不可识别，回到第 4 章检查信息条件；奖励是否表达了真正意图，回到第 5 章；新任务怎样识别与适应，由第 6 章讨论；其他参与者如何响应，由第 7 章提供模型。可信性并非求解器结束后附加的称号，而是对明确要求、适用前提与有效证据的持续对应。

第二部分

知识的获取

Knowledge Acquisition

第三部分

知识的演进与迁移

Knowledge Evolution and Transfer

参考文献

Y. Abbasi-Yadkori, D. Pál, C. Szepesvári, *Improved Algorithms for Linear Stochastic Bandits* In Advances in Neural Information Processing Systems, 2011, pp. 2312–2320.

P. Abbeel, A. Y. Ng, *Apprenticeship Learning via Inverse Reinforcement Learning* In Proceedings of the 21st International Conference on Machine Learning, 2004.

A. Abdolmaleki, J. T. Springenberg, Y. Tassa, R. Munos, N. Heess, M. Riedmiller, *Maximum a Posteriori Policy Optimisation* In International Conference on Learning Representations, 2018.

J. Achiam, D. Held, A. Tamar, P. Abbeel, *Constrained Policy Optimization* In Proceedings of the 34th International Conference on Machine Learning, 2017, pp. 22–31.

A. Agarwal, S. Kakade, L. F. Yang, *Model-Based Reinforcement Learning with a Generative Model is Minimax Optimal* In Proceedings of Thirty Third Conference on Learning Theory, 2020, pp. 67–83.

R. Agarwal, M. Schwarzer, P. S. Castro, A. Courville, M. G. Bellemare, *Deep Reinforcement Learning at the Edge of the Statistical Precipice* In Advances in Neural Information Processing Systems, 2021.

C. C. Aggarwal, *Recommender Systems*, Springer, 2016.

M. Alshiekh, R. Bloem, R. Ehlers, B. Könighofer, S. Niekum, U. Topcu, *Safe Reinforcement Learning via Shielding* In Proceedings of the AAAI Conference on Artificial Intelligence, 2018.

E. Altman, *Constrained Markov Decision Processes*, Chapman & Hall/CRC, 1999.

A. D. Ames, X. Xu, J. W. Grizzle, P. Tabuada, *Control Barrier Function Based Quadratic Programs for Safety Critical Systems* In IEEE Transactions on Automatic Control, 2017, vol. 62, no. 8, pp. 3861–3876.

M. Andrychowicz, F. Wolski, A. Ray, J. Schneider, R. Fong, P. Welinder, B. McGrew, J. Tobin, P. Abbeel, W. Zaremba, *Hindsight Experience Replay* In Advances in Neural Information Processing Systems, 2017.

J. A. Arjona-Medina, M. Gillhofer, M. Widrich, T. Unterthiner, J. Brandstetter, S. Hochreiter, *RUDDER: Return Decomposition for Delayed Rewards* In Advances in Neural Information Processing Systems, 2019.

P. Auer, N. Cesa-Bianchi, P. Fischer, *Finite-Time Analysis of the Multiarmed Bandit Problem* In Machine Learning, 2002, vol. 47, pp. 235–256.

P. Auer, N. Cesa-Bianchi, Y. Freund, R. E. Schapire, *The Nonstochastic Multiarmed Bandit Problem* In SIAM Journal on Computing, 2002, vol. 32, no. 1, pp. 48–77.

M. G. Azar, I. Osband, R. Munos, *Minimax Regret Bounds for Reinforcement Learning* In Proceedings of the 34th International Conference on Machine Learning, 2017, pp. 263–272.

P.-L. Bacon, J. Harb, D. Precup, *The Option-Critic Architecture* In Proceedings of the AAAI Conference on Artificial Intelligence, 2017, pp. 1726–1734.

A. P. Badia, B. Piot, S. Kapturowski, P. Sprechmann, A. Vitvitskyi, Z. D. Guo, C. Blundell, *Agent57: Outperforming the Atari Human Benchmark* In Proceedings of the 37th International Conference on Machine Learning, 2020, pp. 507–517.

Y. Bai, S. Kadavath, S. Kundu, A. Askell, J. Kernion, A. Jones, A. Chen, A. Goldie, A. Mirhoseini, C. McKinnon, C. Chen, C. Olsson, C. Olah, D. Hernandez, D. Drain, D. Ganguli, D. Li, E. Tran-Johnson, E. Perez, J. Kerr, J. Mueller, J. Ladish, J. Landau, K. Ndousse, K. Lukosuite, L. Lovitt, M. Sellitto, N. Elhage, N. Schiefer, N. Mercado, N. DasSarma, R. Lasenby, R. Larson, S. Ringer, S. Johnston, S. Kravec, S. El Showk, S. Fort, T. Lanham, T. Telleen-Lawton, T. Conerly, T. Henighan, T. Hume, S. R. Bowman, Z. Hatfield-Dodds, B. Mann, D. Amodei, N. Joseph, S. McCandlish, T. Brown, J. Kaplan, *Constitutional AI: Harmlessness from AI Feedback* In arXiv preprint arXiv:2212.08073, 2022.

L. Baird, *Residual Algorithms: Reinforcement Learning with Function Approximation* In Proceedings of the Twelfth International Conference on Machine Learning, 1995, pp. 30–37.

A. Barreto, W. Dabney, R. Munos, J. J. Hunt, T. Schaul, H. van Hasselt, D. Silver, *Successor Features for Transfer in Reinforcement Learning* In Advances in Neural Information Processing Systems, 2017.

A. G. Barto, R. S. Sutton, C. W. Anderson, *Neuronlike Adaptive Elements That Can Solve Difficult Learning Control Problems* In IEEE Transactions on Systems, Man, and Cybernetics, 1983, vol. SMC-13, no. 5, pp. 834–846.

J. Bauer, K. Baumli, F. Behbahani, A. Bhoopchand, N. Bradley-Schmieg, M. Chang, N. Clay, A. Collister, V. Dasagi, L. Gonzalez, K. Gregor, E. Hughes, S. Kashem, M. Loks-Thompson, H. Openshaw, J. Parker-

Holder, S. Pathak, N. Perez-Nieves, N. Rakicevic, T. Rocktäschel, Y. Schroecker, S. Singh, J. Sygnowski, K. Tuyls, S. York, A. Zacherl, L. M. Zhang, *Human-Timescale Adaptation in an Open-Ended Task Space* In Proceedings of the 40th International Conference on Machine Learning, 2023, pp. 1887–1935.

A. Begzadic, N. Shinde, S. Tonkens, D. Hirsch, K. Ugalde, M. Yip, J. Cortes, S. Herbert, *Back to Base: Towards Hands-Off Learning via Safe Resets with Reach-Avoid Safety Filters* In Proceedings of the 7th Annual Learning for Dynamics & Control Conference, 2025, pp. 1154–1166.

M. G. Bellemare, W. Dabney, R. Munos, *A Distributional Perspective on Reinforcement Learning* In Proceedings of the 34th International Conference on Machine Learning, 2017, pp. 449–458.

R. Bellman, *Dynamic Programming*, Princeton University Press, 1957.

F. Berkenkamp, M. Turchetta, A. P. Schoellig, A. Krause, *Safe Model-Based Reinforcement Learning with Stability Guarantees* In Advances in Neural Information Processing Systems, 2017.

D. S. Bernstein, R. Givan, N. Immerman, S. Zilberstein, *The Complexity of Decentralized Control of Markov Decision Processes* In Mathematics of Operations Research, 2002, vol. 27, no. 4, pp. 819–840.

D. P. Bertsekas, J. N. Tsitsiklis, *Neuro-Dynamic Programming*, Athena Scientific, 1996.

C. M. Bishop, *Pattern Recognition and Machine Learning*, Springer, 2006, 1st ed.

C. M. Bishop, H. Bishop, *Deep Learning: Foundations and Concepts*, Springer, 2024.

S. Boyd, *Linear Quadratic Regulator: Discrete-Time Finite Horizon*, EE363, Lecture 1, Winter 2008–09, Stanford University, 2009, URL: https://stanford.edu/class/ee363/lectures/dlqr.pdf (visited on 10/04/2026).

R. A. Bradley, M. E. Terry, *Rank Analysis of Incomplete Block Designs: I. The Method of Paired Comparisons* In Biometrika, 1952, vol. 39, no. 3/4, pp. 324–345.

S. J. Bradtke, A. G. Barto, *Linear Least-Squares Algorithms for Temporal Difference Learning* In Machine Learning, 1996, vol. 22, pp. 33–57.

R. I. Brafman, M. Tennenholtz, *R-MAX: A General Polynomial Time Algorithm for Near-Optimal Reinforcement Learning* In Journal of Machine Learning Research, 2002, vol. 3, pp. 213–231.

Y. Burda, H. Edwards, A. Storkey, O. Klimov, *Exploration by Random Network Distillation* In International Conference on Learning Representations, 2019.

M. Carroll, R. Shah, M. K. Ho, T. Griffiths, S. Seshia, P. Abbeel, A. Dragan, *On the Utility of Learning about Humans for Human-AI Coordination* In Advances in Neural Information Processing Systems, 2019.

L. Chen, K. Lu, A. Rajeswaran, K. Lee, A. Grover, M. Laskin, P. Abbeel, A. Srinivas, I. Mordatch, *Decision Transformer: Reinforcement Learning via Sequence Modeling* In Advances in Neural Information Processing Systems, 2021.

Y. Chow, M. Ghavamzadeh, L. Janson, M. Pavone, *Risk-Constrained Reinforcement Learning with Percentile Risk Criteria* In Journal of Machine Learning Research, 2018, vol. 18, no. 167, pp. 1–51.

Y. Chow, A. Tamar, S. Mannor, M. Pavone, *Risk-Sensitive and Robust Decision-Making: A CVaR Optimization Approach* In Advances in Neural Information Processing Systems, 2015.

P. F. Christiano, J. Leike, T. B. Brown, M. Martic, S. Legg, D. Amodei, *Deep Reinforcement Learning from Human Preferences* In Advances in Neural Information Processing Systems 30, 2017, pp. 4299–4307.

K. Chua, R. Calandra, R. McAllister, S. Levine, *Deep Reinforcement Learning in a Handful of Trials Using Probabilistic Dynamics Models* In Advances in Neural Information Processing Systems, 2018.

K. Cobbe, C. Hesse, J. Hilton, J. Schulman, *Leveraging Procedural Generation to Benchmark Reinforcement Learning* In Proceedings of the 37th International Conference on Machine Learning, 2020, pp. 2048–2056.

W. Dabney, G. Ostrovski, D. Silver, R. Munos, *Implicit Quantile Networks for Distributional Reinforcement Learning* In Proceedings of the 35th International Conference on Machine Learning, 2018, pp. 1096–1105.

W. Dabney, M. Rowland, M. G. Bellemare, R. Munos, *Distributional Reinforcement Learning with Quantile Regression* In Proceedings of the AAAI Conference on Artificial Intelligence, 2018, pp. 5779–5786.

A. Das, T. Gervet, J. Romoff, D. Batra, D. Parikh, M. Rabbat, J. Pineau, *TarMAC: Targeted Multi-Agent Communication* In Proceedings of the 36th International Conference on Machine Learning, 2019, pp. 1538–1546.

H. Daumé III, J. Langford, D. Marcu, *Search-Based Structured Prediction* In Machine Learning, 2009, vol. 75, no. 3, pp. 297–325.

P. Dayan, *Improving Generalization for Temporal Difference Learning: The Successor Representation* In Neural Computation, 1993, vol. 5, no. 4, pp. 613–624.

P. Dayan, G. E. Hinton, *Feudal Reinforcement Learning* In Advances in Neural Information Processing Systems, 1993, pp. 271–278.

DeepSeek-AI, *DeepSeek-R1: Incentivizing Reasoning Capability in LLMs via Reinforcement Learning* In arXiv preprint arXiv:2501.12948v1, 2025.

M. P. Deisenroth, A. A. Faisal, C. S. Ong, *Mathematics for Machine Learning*, Cambridge University Press, 2020.

M. P. Deisenroth, C. E. Rasmussen, *PILCO: A Model-Based and Data-Efficient Approach to Policy Search* In Proceedings of the 28th International Conference on Machine Learning, 2011, pp. 465–472.

T. G. Dietterich, *Hierarchical Reinforcement Learning with the MAXQ Value Function Decomposition* In Journal of Artificial Intelligence Research, 2000, vol. 13, pp. 227–303.

Y. Duan, J. Schulman, X. Chen, P. L. Bartlett, I. Sutskever, P. Abbeel, *RL^2: Fast Reinforcement Learning via Slow Reinforcement Learning* In arXiv preprint arXiv:1611.02779, 2016.

A. Ecoffet, J. Huizinga, J. Lehman, K. O. Stanley, J. Clune, *First Return, Then Explore* In Nature, 2021, vol. 590, pp. 580–586.

D. Ernst, P. Geurts, L. Wehenkel, *Tree-Based Batch Mode Reinforcement Learning* In Journal of Machine Learning Research, 2005, vol. 6, pp. 503–556.

L. Espeholt, H. Soyer, R. Munos, K. Simonyan, V. Mnih, T. Ward, Y. Doron, V. Firoiu, T. Harley, I. Dunning, S. Legg, K. Kavukcuoglu, *IMPALA: Scalable Distributed Deep-RL with Importance Weighted Actor-Learner Architectures* In Proceedings of the 35th International Conference on Machine Learning, 2018, pp. 1407–1416.

B. Eysenbach, A. Gupta, J. Ibarz, S. Levine, *Diversity Is All You Need: Learning Skills without a Reward Function* In International Conference on Learning Representations, 2019.

A.-m. Farahmand, C. Szepesvári, R. Munos, *Error Propagation for Approximate Policy and Value Iteration* In Advances in Neural Information Processing Systems, 2010.

Farama Foundation, *Minari: Dataset Standards and Episode Data*, URL: https://minari.farama.org/ (visited on 10/04/2026).

V. Feinberg, A. Wan, I. Stoica, M. I. Jordan, J. E. Gonzalez, S. Levine, *Model-Based Value Estimation for Efficient Model-Free Reinforcement Learning*, 2018, arXiv: 1803.00101.

C. Finn, P. Abbeel, S. Levine, *Model-Agnostic Meta-Learning for Fast Adaptation of Deep Networks* In Proceedings of the 34th International Conference on Machine Learning, 2017, pp. 1126–1135.

J. Foerster, I. A. Assael, N. de Freitas, S. Whiteson, *Learning to Communicate with Deep Multi-Agent Reinforcement Learning* In Advances in Neural Information Processing Systems, 2016.

J. Foerster, R. Y. Chen, M. Al-Shedivat, S. Whiteson, P. Abbeel, I. Mordatch, *Learning with Opponent-Learning Awareness* In Proceedings of the 17th International Conference on Autonomous Agents and Multiagent Systems, 2018, pp. 122–130.

J. Foerster, G. Farquhar, T. Afouras, N. Nardelli, S. Whiteson, *Counterfactual Multi-Agent Policy Gradients* In Proceedings of the AAAI Conference on Artificial Intelligence, 2018.

J. Foerster, N. Nardelli, G. Farquhar, T. Afouras, P. H. S. Torr, P. Kohli, S. Whiteson, *Stabilising Experience Replay for Deep Multi-Agent Reinforcement Learning* In Proceedings of the 34th International Conference on Machine Learning, 2017, pp. 1146–1155.

M. Fortunato, M. G. Azar, B. Piot, J. Menick, I. Osband, A. Graves, V. Mnih, R. Munos, D. Hassabis, O. Pietquin, C. Blundell, S. Legg, *Noisy Networks for Exploration* In International Conference on Learning Representations, 2018.

J. Fu, A. Kumar, O. Nachum, G. Tucker, S. Levine, *D4RL: Datasets for Deep Data-Driven Reinforcement Learning* In arXiv preprint arXiv:2004.07219, 2020.

J. Fu, K. Luo, S. Levine, *Learning Robust Rewards with Adversarial Inverse Reinforcement Learning* In International Conference on Learning Representations, 2018.

S. Fujimoto, S. S. Gu, *A Minimalist Approach to Offline Reinforcement Learning* In Advances in Neural Information Processing Systems, 2021.

S. Fujimoto, H. van Hoof, D. Meger, *Addressing Function Approximation Error in Actor-Critic Methods* In Proceedings of the 35th International Conference on Machine Learning, 2018, pp. 1587–1596.

S. Fujimoto, D. Meger, D. Precup, *Off-Policy Deep Reinforcement Learning without Exploration* In Proceedings of the 36th International Conference on Machine Learning, 2019, pp. 2052–2062.

L. Gao, J. Schulman, J. Hilton, *Scaling Laws for Reward Model Overoptimization* In Proceedings of the 40th International Conference on Machine Learning, 2023, pp. 10835–10866.

D. Garg, S. Chakraborty, C. Cundy, J. Song, M. Geist, S. Ermon, *IQ-Learn: Inverse Soft-Q Learning for Imitation* In Advances in Neural Information Processing Systems, 2021, pp. 4028–4039.

C. Gelada, S. Kumar, J. Buckman, O. Nachum, M. G. Bellemare, *DeepMDP: Learning Continuous Latent Space Models for Representation Learning* In Proceedings of the 36th International Conference on Machine Learning, 2019, pp. 2170–2179.

A. Géron, *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow*, O'Reilly Media, 2022, 3rd ed.

J. C. Gittins, *Bandit Processes and Dynamic Allocation Indices* In Journal of the Royal Statistical Society. Series B (Methodological), 1979, vol. 41, no. 2, pp. 148–177.

R. Givan, T. Dean, M. Greig, *Equivalence Notions and Model Minimization in Markov Decision Processes* In Artificial Intelligence, 2003, vol. 147, no. 1–2, pp. 163–223.

I. Goodfellow, Y. Bengio, A. Courville, *Deep Learning*, MIT Press, 2016.

K. Gregor, D. J. Rezende, D. Wierstra, *Variational Intrinsic Control* In International Conference on Learning Representations, 2017.

C. Grimm, A. Barreto, S. Singh, D. Silver, *The Value Equivalence Principle for Model-Based Reinforcement Learning* In Advances in Neural Information Processing Systems, 2020, pp. 5541–5552.

C. Gulcehre, Z. Wang, A. Novikov, T. L. Paine, S. G. Colmenarejo, K. Zolna, R. Agarwal, J. Merel, D. Mankowitz, C. Paduraru, G. Dulac-Arnold, J. Li, M. Norouzi, M. Hoffman, O. Nachum, G. Tucker, N. Heess, N. de Freitas, *RL Unplugged: A Suite of Benchmarks for Offline Reinforcement Learning* In Advances in Neural Information Processing Systems, 2020.

D. Ha, J. Schmidhuber, *Recurrent World Models Facilitate Policy Evolution* In Advances in Neural Information Processing Systems, 2018.

T. Haarnoja, A. Zhou, P. Abbeel, S. Levine, *Soft Actor-Critic: Off-Policy Maximum Entropy Deep Reinforcement Learning with a Stochastic Actor* In Proceedings of the 35th International Conference on Machine Learning, 2018, pp. 1861–1870.

T. Haarnoja, A. Zhou, K. Hartikainen, G. Tucker, S. Ha, J. Tan, V. Kumar, H. Zhu, A. Gupta, P. Abbeel, S. Levine, *Soft Actor-Critic Algorithms and Applications*, version 2, 2018, arXiv: 1812.05905, (visited on 10/04/2026).

D. Hafner, T. Lillicrap, J. Ba, M. Norouzi, *Dream to Control: Learning Behaviors by Latent Imagination* In International Conference on Learning Representations, 2020.

D. Hafner, T. Lillicrap, I. Fischer, R. Villegas, D. Ha, H. Lee, J. Davidson, *Learning Latent Dynamics for Planning from Pixels* In Proceedings of the 36th International Conference on Machine Learning, 2019, pp. 2555–2565.

D. Hafner, T. Lillicrap, M. Norouzi, J. Ba, *Mastering Atari with Discrete World Models* In International Conference on Learning Representations, 2021.

D. Hafner, J. Pasukonis, J. Ba, T. Lillicrap, *Mastering Diverse Control Tasks through World Models* In Nature, 2025, vol. 640, no. 8059, pp. 647–653.

D. Hafner, W. Yan, T. Lillicrap, *Training Agents Inside of Scalable World Models* In arXiv preprint arXiv:2509.24527, 2025.

N. Hansen, H. Su, X. Wang, *TD-MPC2: Scalable, Robust World Models for Continuous Control* In International Conference on Learning Representations, 2024.

N. A. Hansen, H. Su, X. Wang, *Temporal Difference Learning for Model Predictive Control* In Proceedings of the 39th International Conference on Machine Learning, 2022, pp. 8387–8406.

N. Hansen, A. Ostermeier, *Completely Derandomized Self-Adaptation in Evolution Strategies* In Evolutionary Computation, 2001, vol. 9, no. 2, pp. 159–195.

P. Hansen-Estruch, I. Kostrikov, M. Janner, J. G. Kuba, S. Levine, *IDQL: Implicit Q-Learning as an Actor-Critic Method with Diffusion Policies* In arXiv preprint arXiv:2304.10573, 2023.

S. Hart, A. Mas-Colell, *A Simple Adaptive Procedure Leading to Correlated Equilibrium* In Econometrica, 2000, vol. 68, no. 5, pp. 1127–1150.

H. van Hasselt, *Double Q-Learning* In Advances in Neural Information Processing Systems, 2010, pp. 2613–2621.

H. van Hasselt, A. Guez, D. Silver, *Deep Reinforcement Learning with Double Q-Learning* In Proceedings of the AAAI Conference on Artificial Intelligence, 2016, pp. 2094–2100.

T. Hastie, R. Tibshirani, J. Friedman, *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*, Springer, 2009, 2nd ed.

M. Hausknecht, P. Stone, *Deep Recurrent Q-Learning for Partially Observable MDPs* In AAAI Fall Symposium on Sequential Decision Making for Intelligent Agents, 2015.

Z. He, S. Zhang, Z. Zhou, Y. Yang, Y. Kang, Y. Zhang, L. K. Qiu, T. Y. Tsui, J. Xu, C. Luo, *Agent Lightning v1.0: Towards Harnessed Agentic RL* In arXiv preprint arXiv:2608.17528, 2026.

J. Heinrich, M. Lanctot, D. Silver, *Fictitious Self-Play in Extensive-Form Games* In Proceedings of the 32nd International Conference on Machine Learning, 2015, pp. 805–813.

J. Heinrich, D. Silver, *Deep Reinforcement Learning from Self-Play in Imperfect-Information Games*, 2016, arXiv: 1603.01121, URL: https://arxiv.org/abs/1603.01121v2 (visited on 10/04/2026).

M. Hessel, J. Modayil, H. van Hasselt, T. Schaul, G. Ostrovski, W. Dabney, D. Horgan, B. Piot, M. G. Azar, D. Silver, *Rainbow: Combining Improvements in Deep Reinforcement Learning* In Proceedings of the AAAI Conference on Artificial Intelligence, 2018, pp. 3215–3222.

J. Ho, S. Ermon, *Generative Adversarial Imitation Learning* In Advances in Neural Information Processing Systems, 2016, pp. 4565–4573.

R. A. Howard, *Dynamic Programming and Markov Processes*, The Technology Press of the Massachusetts Institute of Technology, 1960.

S. R. Howard, A. Ramdas, J. McAuliffe, J. Sekhon, *Time-Uniform, Nonparametric, Nonasymptotic Confidence Sequences* In The Annals of Statistics, 2021, vol. 49, no. 2, pp. 1055–1080.

H. Hu, A. Lerer, A. Peysakhovich, J. Foerster, *Other-Play for Zero-Shot Coordination* In Proceedings of the 37th International Conference on Machine Learning, 2020, pp. 4399–4410.

J. Hu, M. P. Wellman, *Nash Q-Learning for General-Sum Stochastic Games* In Journal of Machine Learning Research, 2003, vol. 4, pp. 1039–1069.

C. Huyen, *Designing Machine Learning Systems*, O'Reilly Media, 2022.

T. Jaksch, R. Ortner, P. Auer, *Near-Optimal Regret Bounds for Reinforcement Learning* In Journal of Machine Learning Research, 2010, vol. 11, no. 51, pp. 1563–1600.

G. James, D. Witten, T. Hastie, R. Tibshirani, *An Introduction to Statistical Learning*, Springer, 2021, 2nd ed.

M. Janner, Y. Du, J. Tenenbaum, S. Levine, *Planning with Diffusion for Flexible Behavior Synthesis* In Proceedings of the 39th International Conference on Machine Learning, 2022, pp. 9902–9915.

M. Janner, J. Fu, M. Zhang, S. Levine, *When to Trust Your Model: Model-Based Policy Optimization* In Advances in Neural Information Processing Systems, 2019.

M. Janner, Q. Li, S. Levine, *Offline Reinforcement Learning as One Big Sequence Modeling Problem* In Advances in Neural Information Processing Systems, 2021.

N. Jiang, A. Krishnamurthy, A. Agarwal, J. Langford, R. E. Schapire, *Contextual Decision Processes with Low Bellman Rank Are PAC-Learnable* In Proceedings of the 34th International Conference on Machine Learning, 2017, pp. 1704–1713.

N. Jiang, L. Li, *Doubly Robust Off-policy Value Evaluation for Reinforcement Learning* In Proceedings of the 33rd International Conference on Machine Learning, 2016, pp. 652–661.

C. Jin, Q. Liu, S. Miryoosefi, *Bellman Eluder Dimension: New Rich Classes of RL Problems, and Sample-Efficient Algorithms* In Advances in Neural Information Processing Systems, 2021.

C. Jin, Z. Yang, Z. Wang, M. I. Jordan, *Provably Efficient Reinforcement Learning with Linear Function Approximation* In Proceedings of Thirty Third Conference on Learning Theory, 2020, pp. 2137–2143.

D. Jurafsky, J. H. Martin, *Speech and Language Processing*, Prentice Hall, 2009, 2nd ed.

L. P. Kaelbling, M. L. Littman, A. R. Cassandra, *Planning and Acting in Partially Observable Stochastic Domains* In Artificial Intelligence, 1998, vol. 101, no. 1–2, pp. 99–134.

S. M. Kakade, *A Natural Policy Gradient* In Advances in Neural Information Processing Systems, 2002, pp. 1531–1538.

R. E. Kalman, *A New Approach to Linear Filtering and Prediction Problems* In Journal of Basic Engineering, 1960, vol. 82, no. 1, pp. 35–45.

S. Kalyanakrishnan, A. Tewari, P. Auer, P. Stone, *PAC Subset Selection in Stochastic Multi-Armed Bandits* In Proceedings of the 29th International Conference on Machine Learning, 2012, pp. 655–662.

S. Kapturowski, G. Ostrovski, J. Quan, R. Munos, W. Dabney, *Recurrent Experience Replay in Distributed Reinforcement Learning* In International Conference on Learning Representations, 2019.

E. Kaufmann, O. Cappé, A. Garivier, *On the Complexity of Best-Arm Identification in Multi-Armed Bandit Models* In Journal of Machine Learning Research, 2016, vol. 17, no. 1, pp. 1–42.

M. Kearns, Y. Mansour, A. Y. Ng, *A Sparse Sampling Algorithm for Near-Optimal Planning in Large Markov Decision Processes* In Machine Learning, 2002, vol. 49, pp. 193–208.

M. Kearns, S. Singh, *Near-Optimal Reinforcement Learning in Polynomial Time* In Machine Learning, 2002, vol. 49, pp. 209–232.

R. Kidambi, A. Rajeswaran, P. Netrapalli, T. Joachims, *MOReL: Model-Based Offline Reinforcement Learning* In Advances in Neural Information Processing Systems, 2020.

C. Kim, H. Lee, Y. Seo, K. Lee, Y. Zhu, *DEAS: DEtached Value Learning with Action Sequence for Scalable Offline RL* In International Conference on Learning Representations, 2026.

M. Kleppmann, C. Riccomini, *Designing Data-Intensive Applications*, O'Reilly Media, 2026, 2nd ed.

W. B. Knox, P. Stone, *Interactively Shaping Agents via Human Reinforcement: The TAMER Framework* In Proceedings of the Fifth International Conference on Knowledge Capture, 2009, pp. 9–16.

L. Kocsis, C. Szepesvári, *Bandit Based Monte-Carlo Planning* In Machine Learning: ECML 2006, 2006, pp. 282–293.

D. Koller, N. Friedman, *Probabilistic Graphical Models: Principles and Techniques*, MIT Press, 2009.

V. R. Konda, J. N. Tsitsiklis, *Actor-Critic Algorithms* In Advances in Neural Information Processing Systems, 2000, pp. 1008–1014.

I. Kostrikov, A. Nair, S. Levine, *Offline Reinforcement Learning with Implicit Q-Learning* In International Conference on Learning Representations, 2022.

I. Kostrikov, D. Yarats, R. Fergus, *Image Augmentation Is All You Need: Regularizing Deep Reinforcement Learning from Pixels* In International Conference on Learning Representations, 2021.

A. Kumar, J. Fu, G. Tucker, S. Levine, *Stabilizing Off-Policy Q-Learning via Bootstrapping Error Reduction* In Advances in Neural Information Processing Systems, 2019.

A. Kumar, A. Zhou, G. Tucker, S. Levine, *Conservative Q-Learning for Offline Reinforcement Learning* In Advances in Neural Information Processing Systems, 2020, pp. 1179–1191.

M. G. Lagoudakis, R. Parr, *Least-Squares Policy Iteration* In Journal of Machine Learning Research, 2003, vol. 4, pp. 1107–1149.

T. L. Lai, H. Robbins, *Asymptotically Efficient Adaptive Allocation Rules* In Advances in Applied Mathematics, 1985, vol. 6, no. 1, pp. 4–22.

M. Lanctot, V. Zambaldi, A. Gruslys, A. Lazaridou, K. Tuyls, J. Perolat, D. Silver, T. Graepel, *A Unified Game-Theoretic Approach to Multiagent Reinforcement Learning* In Advances in Neural Information Processing Systems, 2017.

R. Laroche, P. Trichelair, R. Tachet des Combes, *Safe Policy Improvement with Baseline Bootstrapping* In Proceedings of the 36th International Conference on Machine Learning, 2019, pp. 3652–3661.

M. Laskin, H. Liu, X. B. Peng, D. Yarats, A. Rajeswaran, P. Abbeel, *Unsupervised Reinforcement Learning with Contrastive Intrinsic Control* In Advances in Neural Information Processing Systems, 2022, pp. 34478–34491.

M. Laskin, A. Srinivas, P. Abbeel, *CURL: Contrastive Unsupervised Representations for Reinforcement Learning* In Proceedings of the 37th International Conference on Machine Learning, 2020, pp. 5639–5650.

M. Laskin, L. Wang, J. Oh, E. Parisotto, S. Spencer, R. Steigerwald, D. Strouse, S. Hansen, A. Filos, E. Brooks, M. Gazeau, H. Sahni, S. Singh, V. Mnih, *In-context Reinforcement Learning with Algorithm Distillation* In International Conference on Learning Representations, 2023.

H. Le, C. Voloshin, Y. Yue, *Batch Policy Learning under Constraints* In Proceedings of the 36th International Conference on Machine Learning, 2019, pp. 3703–3712.

J. Lee, A. Xie, A. Pacchiano, Y. Chandak, C. Finn, O. Nachum, E. Brunskill, *Supervised Pretraining Can Learn In-Context Reinforcement Learning* In Advances in Neural Information Processing Systems, 2023, pp. 43057–43083.

S. Levine, *Reinforcement Learning and Control as Probabilistic Inference: Tutorial and Review*, 2018, arXiv: 1805.00909.

A. Levy, G. Konidaris, R. Platt, K. Saenko, *Learning Multi-Level Hierarchies with Hindsight* In International Conference on Learning Representations, 2019.

H. Lightman, V. Kosaraju, Y. Burda, H. Edwards, B. Baker, T. Lee, J. Leike, J. Schulman, I. Sutskever, K. Cobbe, *Let's Verify Step by Step* In International Conference on Learning Representations, 2024, pp. 39578–39601.

T. P. Lillicrap, J. J. Hunt, A. Pritzel, N. Heess, T. Erez, Y. Tassa, D. Silver, D. Wierstra, *Continuous Control with Deep Reinforcement Learning* In International Conference on Learning Representations, 2016.

M. L. Littman, *Markov Games as a Framework for Multi-Agent Reinforcement Learning* In Machine Learning Proceedings 1994, 1994, pp. 157–163.

M. L. Littman, R. S. Sutton, S. Singh, *Predictive Representations of State* In Advances in Neural Information Processing Systems, 2001.

J. Liu, F. Liu, Z. Sun, J. Hao, H. Li, B. Wang, D. Dong, C. Chen, Z. Wang, *Scalable In-Context Q-Learning* In International Conference on Learning Representations, 2026.

R. Lowe, Y. Wu, A. Tamar, J. Harb, P. Abbeel, I. Mordatch, *Multi-Agent Actor-Critic for Mixed Cooperative-Competitive Environments* In Advances in Neural Information Processing Systems, 2017.

X. Luo, Y. Zhang, Z. He, Z. Wang, S. Zhao, D. Li, L. K. Qiu, Y. Yang, *Agent Lightning: Train ANY AI Agents with Reinforcement Learning* In arXiv preprint arXiv:2508.03680, 2025.

M. C. Machado, M. G. Bellemare, E. Talvitie, J. Veness, M. Hausknecht, M. Bowling, *Revisiting the Arcade Learning Environment: Evaluation Protocols and Open Problems for General Agents* In Journal of Artificial Intelligence Research, 2018, vol. 61, pp. 523–562.

C. D. Manning, P. Raghavan, H. Schütze, *Introduction to Information Retrieval*, Cambridge University Press, 2008.

T. M. Mitchell, *Machine Learning*, McGraw-Hill, 1997, 1st ed.

V. Mnih, A. P. Badia, M. Mirza, A. Graves, T. Lillicrap, T. Harley, D. Silver, K. Kavukcuoglu, *Asynchronous Methods for Deep Reinforcement Learning* In Proceedings of the 33rd International Conference on Machine Learning, 2016, pp. 1928–1937.

V. Mnih, K. Kavukcuoglu, D. Silver, A. A. Rusu, J. Veness, M. G. Bellemare, A. Graves, M. Riedmiller, A. K. Fidjeland, G. Ostrovski, S. Petersen, C. Beattie, A. Sadik, I. Antonoglou, H. King, D. Kumaran, D. Wierstra, S. Legg, D. Hassabis, *Human-Level Control through Deep Reinforcement Learning* In Nature, 2015, vol. 518, pp. 529–533.

M. Mohri, A. Rostamizadeh, A. Talwalkar, *Foundations of Machine Learning*, The MIT Press, 2018, 2nd ed.

R. Munos, T. Stepleton, A. Harutyunyan, M. G. Bellemare, *Safe and Efficient Off-Policy Reinforcement Learning* In Advances in Neural Information Processing Systems, 2016.

R. Munos, C. Szepesvári, *Finite-Time Bounds for Fitted Value Iteration* In Journal of Machine Learning Research, 2008, vol. 9, pp. 815–857.

K. P. Murphy, *Machine Learning: A Probabilistic Perspective*, MIT Press, 2012.

K. P. Murphy, *Probabilistic Machine Learning*, The MIT Press, 2023.

K. P. Murphy, *Probabilistic Machine Learning: An Introduction*, MIT Press, 2022.

O. Nachum, Y. Chow, B. Dai, L. Li, *DualDICE: Behavior-Agnostic Estimation of Discounted Stationary Distribution Corrections* In Advances in Neural Information Processing Systems, 2019.

O. Nachum, S. Gu, H. Lee, S. Levine, *Data-Efficient Hierarchical Reinforcement Learning* In Advances in Neural Information Processing Systems, 2018.

A. Nair, A. Gupta, M. Dalal, S. Levine, *AWAC: Accelerating Online Reinforcement Learning with Offline Datasets* In arXiv preprint arXiv:2006.09359, 2020.

M. Nakamoto, Y. Zhai, A. Singh, M. S. Mark, Y. Ma, C. Finn, A. Kumar, S. Levine, *Cal-QL: Calibrated Offline RL Pre-Training for Efficient Online Fine-Tuning* In Advances in Neural Information Processing Systems, 2023, pp. 62244–62269.

J. F. Nash Jr., *Equilibrium Points in n-Person Games* In Proceedings of the National Academy of Sciences, 1950, vol. 36, no. 1, pp. 48–49.

A. Y. Ng, D. Harada, S. Russell, *Policy Invariance under Reward Transformations: Theory and Application to Reward Shaping* In Proceedings of the Sixteenth International Conference on Machine Learning, 1999, pp. 278–287.

A. Y. Ng, S. Russell, *Algorithms for Inverse Reinforcement Learning* In Proceedings of the 17th International Conference on Machine Learning, 2000.

M. Oberst, D. Sontag, *Counterfactual Off-Policy Evaluation with Gumbel-Max Structural Causal Models* In Proceedings of the 36th International Conference on Machine Learning, 2019, pp. 4881–4890.

OpenAI, C. Berner, G. Brockman, B. Chan, V. Cheung, P. Dębiak, C. Dennison, D. Farhi, Q. Fischer, S. Hashme, C. Hesse, R. Józefowicz, S. Gray, C. Olsson, J. Pachocki, M. Petrov, H. P. d. O. Pinto, J. Raiman, T. Salimans, J. Schlatter, J. Schneider, S. Sidor, I. Sutskever, J. Tang, F. Wolski, S. Zhang, *Dota 2 with Large Scale Deep Reinforcement Learning*, 2019, arXiv: 1912.06680, URL: https://arxiv.org/abs/1912.06680v1 (visited on 10/04/2026).

I. Osband, D. Russo, B. Van Roy, *(More) Efficient Reinforcement Learning via Posterior Sampling* In Advances in Neural Information Processing Systems, 2013, pp. 3003–3011.

L. Ouyang, J. Wu, X. Jiang, D. Almeida, C. Wainwright, P. Mishkin, C. Zhang, S. Agarwal, K. Slama, A. Ray, J. Schulman, J. Hilton, F. Kelton, L. Miller, M. Simens, A. Askell, P. Welinder, P. F. Christiano, J. Leike, R. Lowe, *Training Language Models to Follow Instructions with Human Feedback* In Advances in Neural Information Processing Systems, 2022, pp. 27730–27744.

F. Pardo, A. Tavakoli, V. Levdik, P. Kormushev, *Time Limits in Reinforcement Learning* In Proceedings of the 35th International Conference on Machine Learning, 2018, pp. 4045–4054.

E. Parisotto, F. Song, J. Rae, R. Pascanu, C. Gulcehre, S. Jayakumar, M. Jaderberg, R. L. Kaufman, A. Clark, S. Noury, M. Botvinick, N. Heess, R. Hadsell, *Stabilizing Transformers for Reinforcement Learning* In Proceedings of the 37th International Conference on Machine Learning, 2020, pp. 7487–7498.

S. Park, K. Frans, B. Eysenbach, S. Levine, *OGBench: Benchmarking Offline Goal-Conditioned RL* In International Conference on Learning Representations, 2025.

D. Pathak, P. Agrawal, A. A. Efros, T. Darrell, *Curiosity-Driven Exploration by Self-Supervised Prediction* In Proceedings of the 34th International Conference on Machine Learning, 2017, pp. 2778–2787.

B. Peng, T. Rashid, C. Schroeder de Witt, P.-A. Kamienny, P. Torr, W. Boehmer, S. Whiteson, *FACMAC: Factored Multi-Agent Centralised Policy Gradients* In Advances in Neural Information Processing Systems, 2021.

J. Pineau, G. Gordon, S. Thrun, *Point-Based Value Iteration: An Anytime Algorithm for POMDPs* In Proceedings of the 18th International Joint Conference on Artificial Intelligence, 2003, pp. 1025–1030.

A. Polubarov, N. Lyubaykin, A. Derevyagin, A. Grishin, I. Saprygin, A. Serkov, M. Averchenko, D. Tikhonov, M. Zhdanov, A. Nikulin, I. Zisman, A. Klepach, A. Zemtsov, V. Kurenkov, *Vintix II: Decision Pre-Trained Transformer is a Scalable In-Context Reinforcement Learner* In International Conference on Learning Representations, 2026.

M. L. Puterman, *Markov Decision Processes: Discrete Stochastic Dynamic Programming*, John Wiley & Sons, 1994.

R. Rafailov, A. Sharma, E. Mitchell, C. D. Manning, S. Ermon, C. Finn, *Direct Preference Optimization: Your Language Model is Secretly a Reward Model* In Advances in Neural Information Processing Systems, 2023, pp. 53728–53741.

K. Rakelly, A. Zhou, D. Quillen, C. Finn, S. Levine, *Efficient Off-Policy Meta-Reinforcement Learning via Probabilistic Context Variables* In Proceedings of the 36th International Conference on Machine Learning, 2019, pp. 5331–5340.

T. Rashid, M. Samvelyan, C. Schroeder, G. Farquhar, J. Foerster, S. Whiteson, *QMIX: Monotonic Value Function Factorisation for Deep Multi-Agent Reinforcement Learning* In Proceedings of the 35th International Conference on Machine Learning, 2018, pp. 4295–4304.

C. E. Rasmussen, C. K. I. Williams, *Gaussian Processes for Machine Learning*, MIT Press, 2006.

Ray RLlib Contributors, *Asynchronous Proximal Policy Optimization (APPO)*, Ray Documentation, URL: https://docs.ray.io/en/latest/rllib/rllib-algorithms.html#asynchronous-proximal-policy-optimization-appo (visited on 10/04/2026).

S. Reed, K. Zolna, E. Parisotto, S. Gómez Colmenarejo, A. Novikov, G. Barth-Maron, M. Giménez, Y. Sulsky, J. Kay, J. T. Springenberg, T. Eccles, J. Bruce, A. Razavi, A. Edwards, N. Heess, Y. Chen, R. Hadsell, O. Vinyals,

M. Bordbar, N. de Freitas, *A Generalist Agent* In Transactions on Machine Learning Research, 2022.

R. T. Rockafellar, S. Uryasev, *Conditional Value-at-Risk for General Loss Distributions* In Journal of Banking & Finance, 2002, vol. 26, no. 7, pp. 1443–1471.

S. Ross, J. A. Bagnell, *Reinforcement and Imitation Learning via Interactive No-Regret Learning*, 2014, arXiv: 1406.5979.

S. Ross, G. Gordon, D. Bagnell, *A Reduction of Imitation Learning and Structured Prediction to No-Regret Online Learning* In Proceedings of the Fourteenth International Conference on Artificial Intelligence and Statistics, 2011, pp. 627–635.

R. Y. Rubinstein, *The Cross-Entropy Method for Combinatorial and Continuous Optimization* In Methodology and Computing in Applied Probability, 1999, vol. 1, pp. 127–190.

D. Russo, B. Van Roy, *Eluder Dimension and the Sample Complexity of Optimistic Exploration* In Advances in Neural Information Processing Systems, 2013.

A. A. Rusu, S. Gómez Colmenarejo, Ç. Gülçehre, G. Desjardins, J. Kirkpatrick, R. Pascanu, V. Mnih, K. Kavukcuoglu, R. Hadsell, *Policy Distillation* In International Conference on Learning Representations, 2016.

A. Ruszczyński, *Risk-Averse Dynamic Programming for Markov Decision Processes* In Mathematical Programming, 2010, vol. 125, no. 2, pp. 235–261.

T. Salimans, J. Ho, X. Chen, S. Sidor, I. Sutskever, *Evolution Strategies as a Scalable Alternative to Reinforcement Learning*, 2017, arXiv: 1703.03864.

A. L. Samuel, *Some Studies in Machine Learning Using the Game of Checkers* In IBM Journal of Research and Development, 1959, vol. 3, no. 3, pp. 210–229.

M. Samvelyan, T. Rashid, C. Schroeder de Witt, G. Farquhar, N. Nardelli, T. G. J. Rudner, C.-M. Hung, P. H. S. Torr, J. Foerster, S. Whiteson, *The StarCraft Multi-Agent Challenge* In Proceedings of the 18th International Conference on Autonomous Agents and Multiagent Systems, 2019, pp. 2186–2188.

T. Schaul, D. Horgan, K. Gregor, D. Silver, *Universal Value Function Approximators* In Proceedings of the 32nd International Conference on Machine Learning, 2015, pp. 1312–1320.

T. Schaul, J. Quan, I. Antonoglou, D. Silver, *Prioritized Experience Replay* In International Conference on Learning Representations, 2016.

J. Schrittwieser, I. Antonoglou, T. Hubert, K. Simonyan, L. Sifre, S. Schmitt, A. Guez, E. Lockhart, D. Hassabis, T. Graepel, T. Lillicrap, D. Silver, *Mastering Atari, Go, Chess and Shogi by Planning with a Learned Model* In Nature, 2020, vol. 588, pp. 604–609.

J. Schulman, S. Levine, P. Moritz, M. Jordan, P. Abbeel, *Trust Region Policy Optimization* In Proceedings of the 32nd International Conference on Machine Learning, 2015, pp. 1889–1897.

J. Schulman, P. Moritz, S. Levine, M. Jordan, P. Abbeel, *High-Dimensional Continuous Control Using Generalized Advantage Estimation* In International Conference on Learning Representations, 2016.

J. Schulman, F. Wolski, P. Dhariwal, A. Radford, O. Klimov, *Proximal Policy Optimization Algorithms*, 2017, arXiv: 1707.06347.

A. Schwartz, *A Reinforcement Learning Method for Maximizing Undiscounted Rewards* In Proceedings of the Tenth International Conference on Machine Learning, 1993, pp. 298–305.

M. Schwarzer, A. Anand, R. Goel, R. D. Hjelm, A. Courville, P. Bachman, *Data-Efficient Reinforcement Learning with Self-Predictive Representations* In International Conference on Learning Representations, 2021.

H. van Seijen, R. S. Sutton, *True Online TD(λ)* In Proceedings of the 31st International Conference on Machine Learning, 2014, pp. 692–700.

S. Shalev-Shwartz, S. Ben-David, *Understanding Machine Learning: From Theory to Algorithms*, Cambridge University Press, 2014, 1st ed.

Z. Shao, P. Wang, Q. Zhu, R. Xu, J. Song, X. Bi, H. Zhang, M. Zhang, Y. K. Li, Y. Wu, D. Guo, *DeepSeekMath: Pushing the Limits of Mathematical Reasoning in Open Language Models*, 2024, arXiv: 2402.03300.

L. S. Shapley, *Stochastic Games* In Proceedings of the National Academy of Sciences, 1953, vol. 39, no. 10, pp. 1095–1100.

A. Sharma, S. Gu, S. Levine, V. Kumar, K. Hausman, *Dynamics-Aware Unsupervised Discovery of Skills* In International Conference on Learning Representations, 2020.

D. Silver, A. Huang, C. J. Maddison, A. Guez, L. Sifre, G. van den Driessche, J. Schrittwieser, I. Antonoglou, V. Panneershelvam, M. Lanctot, S. Dieleman, D. Grewe, J. Nham, N. Kalchbrenner, I. Sutskever, T. Lillicrap, M. Leach, K. Kavukcuoglu, T. Graepel, D. Hassabis, *Mastering the Game of Go with Deep Neural Networks and Tree Search* In Nature, 2016, vol. 529, pp. 484–489.

D. Silver, T. Hubert, J. Schrittwieser, I. Antonoglou, M. Lai, A. Guez, M. Lanctot, L. Sifre, D. Kumaran, T. Graepel, T. Lillicrap, K. Simonyan, D. Hassabis, *A General Reinforcement Learning Algorithm That Masters Chess,*

Shogi, and Go through Self-Play In Science, 2018, vol. 362, no. 6419, pp. 1140–1144.

D. Silver, G. Lever, N. Heess, T. Degris, D. Wierstra, M. Riedmiller, *Deterministic Policy Gradient Algorithms* In Proceedings of the 31st International Conference on Machine Learning, 2014, pp. 387–395.

S. Singh, T. Jaakkola, M. L. Littman, C. Szepesvári, *Convergence Results for Single-Step On-Policy Reinforcement-Learning Algorithms* In Machine Learning, 2000, vol. 38, pp. 287–308.

K. Son, D. Kim, W. J. Kang, D. E. Hostallero, Y. Yi, *QTRAN: Learning to Factorize with Transformation for Cooperative Multi-Agent Reinforcement Learning* In Proceedings of the 36th International Conference on Machine Learning, 2019, pp. 5887–5896.

S. Sukhbaatar, A. Szlam, R. Fergus, *Learning Multiagent Communication with Backpropagation* In Advances in Neural Information Processing Systems, 2016.

W. Sun, N. Jiang, A. Krishnamurthy, A. Agarwal, J. Langford, *Model-Based RL in Contextual Decision Processes: PAC Bounds and Exponential Improvements over Model-Free Approaches* In Proceedings of the Thirty-Second Conference on Learning Theory, 2019, pp. 2898–2933.

P. Sunehag, G. Lever, A. Gruslys, W. M. Czarnecki, V. Zambaldi, M. Jaderberg, M. Lanctot, N. Sonnerat, J. Z. Leibo, K. Tuyls, T. Graepel, *Value-Decomposition Networks for Cooperative Multi-Agent Learning Based on Team Reward* In Proceedings of the 17th International Conference on Autonomous Agents and Multiagent Systems, 2018, pp. 2085–2087.

R. S. Sutton, *Dyna, an Integrated Architecture for Learning, Planning, and Reacting* In SIGART Bulletin, 1991, vol. 2, no. 4, pp. 160–163.

R. S. Sutton, *Learning to Predict by the Methods of Temporal Differences* In Machine Learning, 1988, vol. 3, pp. 9–44.

R. S. Sutton, A. G. Barto, *Reinforcement Learning: An Introduction*, MIT Press, 2018, 2nd ed.

R. S. Sutton, H. R. Maei, D. Precup, S. Bhatnagar, D. Silver, C. Szepesvári, E. Wiewiora, *Fast Gradient-Descent Methods for Temporal-Difference Learning with Linear Function Approximation* In Proceedings of the 26th Annual International Conference on Machine Learning, 2009, pp. 993–1000.

R. S. Sutton, A. R. Mahmood, M. White, *An Emphatic Approach to the Problem of Off-Policy Temporal-Difference Learning* In Journal of Machine Learning Research, 2016, vol. 17, no. 73, pp. 1–29.

R. S. Sutton, D. McAllester, S. Singh, Y. Mansour, *Policy Gradient Methods for Reinforcement Learning with Function Approximation* In Advances in Neural Information Processing Systems, 2000, pp. 1057–1063.

R. S. Sutton, D. Precup, S. Singh, *Between MDPs and Semi-MDPs: A Framework for Temporal Abstraction in Reinforcement Learning* In Artificial Intelligence, 1999, vol. 112, no. 1-2, pp. 181–211.

R. Szeliski, *Computer Vision*, Springer, 2022, 2nd ed.

C. Szepesvári, *Algorithms for Reinforcement Learning*, Morgan & Claypool Publishers, 2010.

D. Tarasov, V. Kurenkov, A. Nikulin, S. Kolesnikov, *Revisiting the Minimalist Approach to Offline Reinforcement Learning* In Advances in Neural Information Processing Systems, 2023, pp. 11592–11620.

Y. Tassa, Y. Doron, A. Muldal, T. Erez, Y. Li, D. de Las Casas, D. Budden, A. Abdolmaleki, J. Merel, A. Lefrancq, T. Lillicrap, M. Riedmiller, *DeepMind Control Suite*, 2018, arXiv: 1801.00690.

G. Tennenholtz, U. Shalit, S. Mannor, *Off-Policy Evaluation in Partially Observable Environments* In Proceedings of the AAAI Conference on Artificial Intelligence, 2020, vol. 34, no. 6, pp. 10276–10283.

J. K. Terry, B. Black, N. Grammel, M. Jayakumar, A. Hari, R. Sullivan, L. Santos, R. Perez, C. Horsch, C. Dieffendahl, N. L. Williams, Y. Lokesh, P. Ravi, *PettingZoo: Gym for Multi-Agent Reinforcement Learning* In Advances in Neural Information Processing Systems, 2021.

C. Tessler, D. J. Mankowitz, S. Mannor, *Reward Constrained Policy Optimization* In International Conference on Learning Representations, 2019.

E. L. Thorndike, *Animal Intelligence: Experimental Studies*, The Macmillan Company, 1911.

E. Todorov, *Linearly-Solvable Markov Decision Problems* In Advances in Neural Information Processing Systems, 2006.

D. M. Topkis, *Minimizing a Submodular Function on a Lattice* In Operations Research, 1978, vol. 26, no. 2, pp. 305–321.

K. Van Moffaert, A. Nowé, *Multi-Objective Reinforcement Learning Using Sets of Pareto Dominating Policies* In Journal of Machine Learning Research, 2014, vol. 15, no. 107, pp. 3663–3692.

O. Vinyals, I. Babuschkin, W. M. Czarnecki, M. Mathieu, A. Dudzik, J. Chung, D. H. Choi, R. Powell, T. Ewalds, P. Georgiev, J. Oh, D. Horgan, M. Kroiss, I. Danihelka, A. Huang, L. Sifre, T. Cai, J. P. Agapiou, M. Jaderberg, A. S. Vezhnevets, R. Leblond, T. Pohlen, V. Dalibard, D. Budden, Y. Sulsky, J. Molloy, T. L. Paine, C. Gulcehre, Z. Wang, T. Pfaff, Y. Wu, R. Ring, D. Yogatama, D. Wünsch, K. McKinney, O. Smith,

T. Schaul, T. Lillicrap, K. Kavukcuoglu, D. Hassabis, C. Apps, D. Silver, *Grandmaster Level in StarCraft II Using Multi-Agent Reinforcement Learning* In Nature, 2019, vol. 575, pp. 350–354.

K. P. Wabersich, M. N. Zeilinger, *A Predictive Safety Filter for Learning-Based Control of Constrained Nonlinear Dynamical Systems* In Automatica, 2021, vol. 129, 109597.

Y. Wan, A. Naik, R. S. Sutton, *Learning and Planning in Average-Reward Markov Decision Processes* In Proceedings of the 38th International Conference on Machine Learning, 2021, pp. 10653–10662.

J. Wang, Z. Ren, T. Liu, Y. Yu, C. Zhang, *QPLEX: Duplex Dueling Multi-Agent Q-Learning* In International Conference on Learning Representations, 2021.

Z. Wang, J. J. Hunt, M. Zhou, *Diffusion Policies as an Expressive Policy Class for Offline Reinforcement Learning* In International Conference on Learning Representations, 2023.

Z. Wang, V. Bapst, N. Heess, V. Mnih, R. Munos, K. Kavukcuoglu, N. de Freitas, *Sample Efficient Actor-Critic with Experience Replay* In International Conference on Learning Representations, 2017.

Z. Wang, T. Schaul, M. Hessel, H. van Hasselt, M. Lanctot, N. de Freitas, *Dueling Network Architectures for Deep Reinforcement Learning* In Proceedings of the 33rd International Conference on Machine Learning, 2016, pp. 1995–2003.

C. J. C. H. Watkins, P. Dayan, *Q-Learning* In Machine Learning, 1992, vol. 8, pp. 279–292.

C.-Y. Wei, H. Luo, *Non-stationary Reinforcement Learning without Prior Knowledge: an Optimal Black-box Approach* In Proceedings of Thirty Fourth Conference on Learning Theory, 2021, pp. 4300–4354.

W. Wiesemann, D. Kuhn, B. Rustem, *Robust Markov Decision Processes* In Mathematics of Operations Research, 2013, vol. 38, no. 1, pp. 153–183.

G. Williams, A. Aldrich, E. A. Theodorou, *Model Predictive Path Integral Control: From Theory to Parallel Computation* In Journal of Guidance, Control, and Dynamics, 2017, vol. 40, no. 2, pp. 344–357.

R. J. Williams, *Simple Statistical Gradient-Following Algorithms for Connectionist Reinforcement Learning* In Machine Learning, 1992, vol. 8, pp. 229–256.

Y. Wu, G. Tucker, O. Nachum, *Behavior Regularized Offline Reinforcement Learning* In arXiv preprint arXiv:1911.11361, 2019.

H. Xu, S. Mannor, *Distributionally Robust Markov Decision Processes* In Advances in Neural Information Processing Systems, 2010.

Y. Yang, R. Luo, M. Li, M. Zhou, W. Zhang, J. Wang, *Mean Field Multi-Agent Reinforcement Learning* In Proceedings of the 35th International Conference on Machine Learning, 2018, pp. 5571–5580.

W. Ye, S. Liu, T. Kurutach, P. Abbeel, Y. Gao, *Mastering Atari Games with Limited Data* In Advances in Neural Information Processing Systems, 2021.

C. Yu, A. Velu, E. Vinitsky, J. Gao, Y. Wang, A. Bayen, Y. Wu, *The Surprising Effectiveness of PPO in Cooperative Multi-Agent Games* In Advances in Neural Information Processing Systems, 2022, pp. 24611–24624.

Q. Yu, Z. Zhang, R. Zhu, Y. Yuan, X. Zuo, Y. Yue, W. Dai, T. Fan, G. Liu, J. Liu, L. Liu, X. Liu, H. Lin, Z. Lin, B. Ma, G. Sheng, Y. Tong, C. Zhang, M. Zhang, R. Zhang, W. Zhang, H. Zhu, J. Zhu, J. Chen, J. Chen, C. Wang, H. Yu, Y. Song, X. Wei, H. Zhou, J. Liu, W.-Y. Ma, Y.-Q. Zhang, L. Yan, Y. Wu, M. Wang, *DAPO: An Open-Source LLM Reinforcement Learning System at Scale* In Advances in Neural Information Processing Systems, 2025, pp. 113222–113244.

T. Yu, A. Kumar, R. Rafailov, A. Rajeswaran, S. Levine, C. Finn, *COMBO: Conservative Offline Model-Based Policy Optimization* In Advances in Neural Information Processing Systems, 2021.

T. Yu, G. Thomas, L. Yu, S. Ermon, J. Zou, S. Levine, C. Finn, T. Ma, *MOPO: Model-based Offline Policy Optimization* In Advances in Neural Information Processing Systems, 2020.

A. Zhang, Z. C. Lipton, M. Li, A. J. Smola, *Dive into Deep Learning*, Cambridge University Press, 2023.

Y. Zhu, L. Ying, *Borrowing From the Future: An Attempt to Address Double Sampling* In Proceedings of The First Mathematical and Scientific Machine Learning Conference, 2020, pp. 246–268.

B. D. Ziebart, A. L. Maas, J. A. Bagnell, A. K. Dey, *Maximum Entropy Inverse Reinforcement Learning* In Proceedings of the Twenty-Third AAAI Conference on Artificial Intelligence, 2008, pp. 1433–1438.

M. Zinkevich, M. Johanson, M. Bowling, C. Piccione, *Regret Minimization in Games with Incomplete Information* In Advances in Neural Information Processing Systems, 2007.

L. Zintgraf, K. Shiarlis, M. Igl, S. Schulze, Y. Gal, K. Hofmann, S. Whiteson, *VariBAD: A Very Good Method for Bayes-Adaptive Deep RL via Meta-Learning* In International Conference on Learning Representations, 2020.

周志华, 机器学习, 清华大学出版社, 2016, 1st ed.

李航, 统计学习方法, 清华大学出版社, 2019, 2nd ed.

邱锡鹏, 神经网络与深度学习, 机械工业出版社, 2020.

索引

一般和，general-sum，296
上下文 MDP，contextual MDP，264
上下文老虎机，contextual bandit，87
不可区分问题对，indistinguishable problem pair，79
世界模型，world model，35
两人零和，two-player zero-sum，296
个体与整体最大化一致性，individual-global-max，311
临时团队协作，ad hoc teamwork，327
主动辨识，active identification，260
事后经验回放，hindsight experience replay，268
交叉熵方法，cross-entropy method，128
代理奖励，proxy reward，223
价值函数，value function，18
价值迭代，value iteration，47
任务信念，task belief，276
优势，advantage，18
保守 Q 学习，conservative Q-learning，205
信念 MDP，belief MDP，189
信念状态，belief state，185
信息集，information set，297
状态空间，state space，3
状态聚合，state aggregation，70
环境，environment，2
生成对抗模仿学习，generative adversarial imitation learning，228
生成模型，generative model，25，162
生成模型访问，generative model access，39
目标策略，target policy，12
直接偏好优化，direct preference optimization，235
相关均衡，correlated equilibrium，303
确定性动力学模型，deterministic dynamics model，130
示范，demonstration，221
离策略评价，off-policy evaluation，196
稀疏采样，sparse sampling，65
策略，policy，10
策略优化，policy optimization，113
策略空间响应预言机，policy-space response oracles，322
策略蒸馏，policy distillation，275
策略评价，policy evaluation，23
简单遗憾，simple regret，85
算术运行时间，arithmetic running time，77
粒度，granularity，221
粗相关均衡，coarse correlated equilibrium，303
精确期望访问，exact expectation access，39
累积遗憾，cumulative regret，85
约束策略优化，constrained policy optimization，355
约束马尔可夫决策过程，constrained Markov decision process，352
线性二次调节器，linear quadratic regulator，54
组合泛化，compositional generalization，268
组相对策略优化，group relative policy optimization，236
经典冻结型 Markov 老虎机，rested Markov bandit，61
结果反馈，outcome feedback，236
绝对连续，absolutely continuous，195
置信上界，upper confidence bound，86
置换等变性，permutation equivariance，325
自举，bootstrapping，94
自然梯度，natural gradient，118
蒙特卡罗，Monte Carlo，93
蒙特卡罗树搜索，Monte Carlo tree search，67
行为克隆，behavior cloning，202，224
行为策略，behavior strategy，12
行为要求，behavioral requirement，223
行动者—评论家，actor–critic，28，121
覆盖，cover，85
观测混叠，observation aliasing，184
认知不确定性，epistemic uncertainty，84
评分，rating，221
贝叶斯模型，Bayesian model，130
贝叶斯自适应 MDP，Bayes-adaptive MDP，264

负迁移，negative transfer，290
ε-贪心，epsilon-greedy，86
资格迹，eligibility trace，95
输入：，Input:，45，107，207，212，226，255，342，353，361
输出：，Output:，45，107，207，212，226，255，342
边界价值评估，boundary value evaluation，66
过度优化，overoptimization，248
过程反馈，process feedback，236
适应后回报，post-adaptation return，289
逆强化学习，inverse reinforcement learning，229
逆软 Q 学习，Inverse soft-Q Learning，229
逐次淘汰，successive elimination，90
递减差分，decreasing differences，58
通用价值函数逼近器，universal value function approximator，271
遗憾匹配，regret matching，319
部分可观测随机博弈，partially observable stochastic game，297
部分可观测马尔可夫决策过程，partially observable Markov decision process，184
阈值策略，threshold policy，58
随机动力学模型，stochastic dynamics model，130
隐式 Q 学习，implicit Q-learning，205
隐藏混杂，hidden confounding，214
集中训练、分散执行，centralized training with decentralized execution，298
集成模型，ensemble model，130
零样本协调，zero-shot coordination，327
零样本回报，zero-shot return，288
零样本执行，zero-shot execution，261
鞍点，saddle point，302
预测状态表示，predictive state representation，187
预算内适应曲线，adaptation curve within budget，289
风险准则，risk criterion，338
马尔可夫决策过程，Markov decision process，5
验证反馈，verification feedback，221
鲁棒要求，robustness requirement，338

Bellman 备份，Bellman backup，42
Bellman 封闭性，Bellman closure，54
Bellman 期望关系，Bellman expectation relation，21
Bellman 残差，Bellman residual，43
Bradley–Terry 模型，Bradley–Terry model，231

KL 控制，Kullback–Leibler control，56

Nash 均衡，Nash equilibrium，303

Pareto 最优，Pareto optimal，245

Riccati 递推，Riccati recursion，55
rollout，66

Thompson 采样，Thompson sampling，86

UCT，upper confidence bounds applied to trees，67

偏好，preference，221
偶然不确定性，aleatoric uncertainty，84
共享结构，shared structure，262
分布式价值学习，distributional value learning，109
分散部分可观测马尔可夫决策过程，decentralized POMDP，297
动作空间，action space，3
单调策略，monotone policy，58
历史任务信息，historical task information，260
原则指导反馈，constitutional feedback，238
双重稳健估计，doubly robust estimation，198
双重采样，double sampling，103
反事实遗憾最小化，counterfactual regret minimization，319
可识别性，identifiability，194
可靠性，reliability，339
可验证奖励，verifiable reward，236
后继特征，successor features，265
后继表示，successor representation，272
回报，return，14，94
固定经验，fixed experience，183
基于 AI 反馈的强化学习，reinforcement learning from AI feedback，238
基于人类反馈的强化学习，reinforcement learning from human feedback，231
基函数展开，basis function expansion，70
基库存策略，base-stock policy，58
基线，baseline，115
奖励归因，reward credit assignment，222
奖励投机，reward hacking，248
奖励重分配，reward redistribution，239
存储复杂度，space complexity，77
安全约束，safety constraint，338
安全证书，safety certificate，361
完全合作，fully cooperative，296
完全回忆，perfect recall，298
对抗逆强化学习，adversarial inverse reinforcement learning，248

少样本适应，few-shot adaptation，261
差分价值，differential value，101
差分奖励，difference reward，310
平均奖励增益，average-reward gain，101
平稳策略，stationary policy，10
并行深度，parallel depth，77
广义优势估计，generalized advantage estimation，117
广义策略改进，generalized policy improvement，273
广义策略迭代，generalized policy iteration，45
强化学习，reinforcement learning，2

批量约束 Q 学习，batch-constrained Q-learning，203
技能变量，skill variable，158
折扣占用度量，discounted occupancy measure，12
拟合 Q 评价，fitted Q evaluation，198
持续在线交互，continual online interaction，183
持续适应，continual adaptation，261
探索，exploration，23
控制，control，23
控制即推断，control as inference，128
效用，utility，223

数据集聚合，Dataset Aggregation，226
时序差分，temporal difference，27，93
显式任务描述，explicit task description，260
智能体，agent，2
最佳响应，best response，302
最大熵强化学习，maximum entropy reinforcement learning，124
最终策略损失，final policy loss，85
有限新增交互，limited additional interaction，183
期望分位数，expectile，205
机会约束，chance constraint，356
条件风险映射，conditional risk mapping，343
标量化，scalarization，245
模型价值扩展，model-based value expansion，134
模型利用偏差，model exploitation，141
模型无关元学习，model-agnostic meta-learning，275
模型调用复杂度，model query complexity，77
正迁移，positive transfer，290
渐进加宽，progressive widening，66
滚动时域规划，receding-horizon planning，63
潜势型奖励塑形，potential-based reward shaping，241