



MACHINE LEARNING NOTES

机器学习笔记

卷一：数学准备

施晓罡

2026 年 · 第一版



MACHINE LEARNING NOTES

机器学习笔记

卷一：数学准备

施晓罡

2026 年 · 第一版

机器学习笔记

MACHINE LEARNING NOTES

作者：施晓罡

版本：第一版

年份：2026

Copyright © 2026 施晓罡



Licensed under the Creative Commons Attribution-NonCommercial-NoDerivatives 4.0 International License (the "License");

You may not use this file except in compliance with the License.

You may obtain a copy of the License at

<https://creativecommons.org/licenses/by-nc-nd/4.0/>

Unless required by applicable law or agreed to in writing, software distributed under the License is distributed on an "AS IS" BASIS, WITHOUT WARRANTIES OR CONDITIONS OF ANY KIND, either express or implied. See the License for the specific language governing permissions and limitations under the License.





前言

本书目标

机器学习把数据、模型和计算连接起来，但理解一种方法，不能只记住模型名称或训练步骤。还需要知道模型能够表示什么规律，学习结论依赖哪些数据与假设，什么证据足以支持评价，以及方法进入具体应用和运行系统后会受到哪些约束。本书沿着这些联系组织内容，希望读者不仅会使用算法，也能解释一个结果为何成立、何时可信，以及怎样把它放入完整的技术过程。

本书面向已经具备基本微积分、线性代数、概率统计和编程基础，希望系统理解机器学习的读者。正文会在需要时回顾具体工具，但不以这些基础课程的完整讲解为目标。阅读后，读者应能从任务和证据出发比较模型与学习方式，并把理论条件、实验评价、应用要求和系统实现放在同一条推理链上考察。

本书内容

全书分为六卷。第一卷“数学准备”建立分析、代数、概率、离散结构与动态决策的共同语言。第二卷“基础、理论和可信性”说明学习如何发生、学习保证依赖哪些条件，以及可靠性、鲁棒性、公平性和隐私等可信要求应由什么证据支持。第三卷“模型”考察经典模型、神经网络模型和概率图模型的结构、推断与学习。第四卷“范式”转向经验和知识的获得方式，讨论交互反馈、有限标注以及任务变化下如何学习、复用和迁移知识。前四卷提供数学工具、分析依据和方法选择，后两卷把这些选择放入实际约束。第五卷“应用”围绕自然语言处理、图像处理、推荐与搜索，说明任务目标、数据形态、模型和评价方式如何相互制约。第六卷“系统”连接数据准备、训练计算、部署服务与运行维护，考察方法如何成为可持续运行的机器学习系统。这样的次序并不表示建模、应用和系统彼此割裂：应用需求决定评价口径，系统条件限制可用方法，而运行中的证据又会促使模型和学习过程重新调整。

参考资料

下面按内容列出可与本书配合阅读的教材。每本书的侧重点不同，读者可以根据正在阅读的卷和需要补充的问题选择查阅，不必按列表顺序通读。

综合与基础

- Mitchell 的 *Machine Learning* 从概念学习、归纳偏置和代表性算法出发，适合查阅机器学习的基本问题和早期统一框架。
- Bishop 的 *Pattern Recognition and Machine Learning* 将概率建模、决策理论、核方法和近似推断联系起来，适合查阅概率视角下的模型与推断方法。
- 周志华的《机器学习》覆盖常用模型、学习理论和实践问题，适合按任务比较方法的基本假设与用途。
- 李航的《统计学习方法（第2版）》以统计机器学习为定位，适合按模型查阅定义、算法和数学推导。
- Deisenroth、Faisal 和 Ong 的 *Mathematics for Machine Learning* 适合补充线性代数、解析几何、矩阵微积分、概率与优化等数学工具。

统计学习与学习理论

- Hastie、Tibshirani 和 Friedman 的 *The Elements of Statistical Learning* 适合查阅回归、分类、正则化、模型选择和统计学习方法。
- Shalev-Shwartz 和 Ben-David 的 *Understanding Machine Learning: From Theory to Algorithms* 适合查阅 PAC 框架、复杂度、泛化界与优化基础。
- Mohri、Rostamizadeh 和 Talwalkar 的 *Foundations of Machine Learning* 适合查阅学习界、核方法、在线学习及其理论保证。
- James、Witten、Hastie 和 Tibshirani 的 *An Introduction to Statistical Learning* 适合结合 R 实例理解回归、分类、重采样、正则化、树模型和无监督学习。

概率模型与图模型

- Murphy 的 *Machine Learning: A Probabilistic Perspective* 以概率视角组织监督学习、无监督学习、潜变量模型和图模型，适合查阅模型间的联系。

- Murphy 的 *Probabilistic Machine Learning: An Introduction* 适合查阅现代概率机器学习的统一记号、计算方法和模型实例。
- Murphy 的 *Probabilistic Machine Learning: Advanced Topics* 适合查阅深度生成模型、状态空间模型、贝叶斯优化和相关近似推断方法。
- Koller 和 Friedman 的 *Probabilistic Graphical Models: Principles and Techniques* 适合系统查阅图模型的表示、精确与近似推断以及参数和结构学习。
- Rasmussen 和 Williams 的 *Gaussian Processes for Machine Learning* 适合深入理解高斯过程、核函数、贝叶斯预测和超参数学习。

神经网络与深度学习

- Goodfellow、Bengio 和 Courville 的 *Deep Learning* 适合查阅神经网络表示、优化、正则化和深度生成模型。
- Bishop 和 Bishop 的 *Deep Learning: Foundations and Concepts* 从概率基础连接常用架构与训练方法，适合查阅相应概念和推导。
- 邱锡鹏的《神经网络与深度学习》适合查阅前馈、卷积、循环、注意力网络及其训练方法。
- Zhang、Lipton、李沐和 Smola 的 *Dive into Deep Learning* 适合结合可运行代码理解神经网络的实现、训练与调参过程。
- Géron 的 *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow* 适合查阅从数据准备、模型训练到评估和部署的实践流程。

强化学习

- Sutton 和 Barto 的 *Reinforcement Learning: An Introduction* 适合查阅马尔可夫决策过程、价值方法、策略方法与函数逼近。
- Szepesvári 的 *Algorithms for Reinforcement Learning* 适合查阅动态规划、Monte Carlo、时序差分和函数逼近算法的数学形式与分析。

应用与系统

- Manning、Raghavan 和 Schütze 的 *Introduction to Information Retrieval* 适合查阅文本表示、索引、检索模型和评价方法。
- Huyen 的 *Designing Machine Learning Systems* 从数据、训练、部署与监控讨论机器学习系统设计，适合查阅模型进入生产环境后的工程约束。

- Jurafsky 和 Martin 的 *Speech and Language Processing* 适合查阅自然语言与语音处理中的语言模型、序列标注、句法分析和语音识别。
- Szeliski 的 *Computer Vision: Algorithms and Applications* 适合查阅成像、特征、几何、识别与图像合成方法。
- Aggarwal 的 *Recommender Systems: The Textbook* 适合查阅协同过滤、基于内容的推荐、矩阵分解和推荐评价。
- Kleppmann 和 Riccomini 的 *Designing Data-Intensive Applications* 适合查阅存储、复制、分区、事务以及流式与批量处理的系统取舍。

上述教材的完整出版信息列于卷末参考文献。

数学符号

下表汇总全书反复使用的记号。各章若赋予符号更具体的含义，会在首次使用时另行说明。

对象与线性代数

对象	常用记号	含义
数集	$\mathbb{N}, \mathbb{Z}, \mathbb{R}, \mathbb{R}_+$	自然数集、整数集、实数集和非负实数集
集合与关系	$x \in A, A \subseteq B, A \cup B, A \cap B, A $	元素属于集合、子集、并集、交集和有限集合的基数
标量	$a, x, \lambda \in \mathbb{R}$	单个数值；小写斜体字母通常表示标量
向量	$\mathbf{x}, \mathbf{w} \in \mathbb{R}^d$	d 维向量；加粗小写字母表示向量
矩阵	$\mathbf{A} \in \mathbb{R}^{m \times n}, \mathbf{A}_{i,j}$	m 行 n 列矩阵及其第 i 行、第 j 列元素
数据与样本	$\mathcal{D} = \{(\mathbf{x}_i, y_i)\}_{i=1}^n$	含 n 个输入标签对的数据集；下标 i 表示样本索引
切片与迭代	$\mathbf{A}_{i,:}, \mathbf{A}_{:,j}, \mathbf{w}^{(t)}$	矩阵的第 i 行、第 j 列，以及第 t 次迭代的向量
Kronecker delta	$\delta_{i,j}$	当 $i = j$ 时取 1，否则取 0
矩阵变换	$\mathbf{A}^\top, \mathbf{A}^{-1}, \mathbf{A}^\dagger, \mathbf{I}_d, \text{tr}(\mathbf{A})$	转置、逆、伪逆、 d 阶单位矩阵和矩阵的迹
代数运算	$\langle \mathbf{x}, \mathbf{y} \rangle, \mathbf{x}^\top \mathbf{A} \mathbf{x}, \sum_i a_i, \prod_i a_i$	内积、二次型、求和与连乘
函数与模型	$f: \mathcal{X} \rightarrow \mathcal{Y}, h_{\mathbf{w}}(\mathbf{x})$	从输入空间到输出空间的函数，以及参数为 $\mathbf{w}$ 的模型
范数与距离	$\ \mathbf{x}\ _p, d(\mathbf{x}, \mathbf{y})$	p 范数与两对象之间的距离；具体定义由上下文给出

微积分与优化

对象	常用记号	含义
导数与梯度	$\frac{df}{dx}, \nabla_{\mathbf{w}} L(\mathbf{w})$	一元导数，以及标量值函数对参数向量的梯度
Jacobian 与 Hessian	$\nabla_{\mathbf{x}} \mathbf{f}, \nabla_{\mathbf{x}}^2 f$	向量值函数的一阶偏导矩阵，以及标量值函数的二阶偏导矩阵
渐近阶	$f(n) = \mathcal{O}(g(n))$	函数增长率的渐近上界
最优化	$\min_{\mathbf{w}} L(\mathbf{w}), \mathbf{w}^* \in \arg \min_{\mathbf{w}} L(\mathbf{w})$	最小目标值与取得最小值的参数；最大化使用 $\max$ 和 $\arg \max$

概率与信息论

对象	常用记号	含义
随机变量与实现	$X, \mathbf{X}, x, \mathbf{x}, p_X(x)$	随机标量、随机向量及其实现值； p_X 表示概率质量或密度函数
联合与条件概率	$p(x, y), p(x \mid y)$	随机变量实现值的联合概率与条件概率
边缘概率	$p(x) = \sum_y p(x, y), p(x) = \int p(x, y) \mathrm{d}y$	分别对离散变量求和或对连续变量积分得到的边缘概率
独立性与抽样	$X \perp Y, X \perp Y \mid Z, X_i \overset{\text{i.i.d.}}{\sim} p$	独立、给定 Z 条件独立，以及独立同分布抽样
矩与相关性	$\mathbb{E}[X], \text{Var}(X), \text{Cov}(X, Y)$	期望、方差和协方差
常用分布	$\text{Bernoulli}(p), \text{Cat}(\boldsymbol{\pi}), \mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma})$	伯努利分布、类别分布和多元高斯分布
事件指示函数	$\mathbb{I}\{A\}$	事件 A 成立时取 1，否则取 0
信息量	$H(p), H(p, q), \text{KL}(p\ q)$	熵、交叉熵和分布 p 相对于 q 的 KL 散度
概率正比关系	$p(\mathbf{x}) \propto q(\mathbf{x})$	忽略归一化常数时的概率正比关系

目录

第一部分	数学语言、分析与最优化	1
第 1 章	集合、函数与证明	2
1.1	集合、关系与函数	2
1.2	索引、有限和与递推	5
1.3	命题、量词与条件	8
1.4	证明、构造与反例	10
1.5	最优值与误差表达	12
1.6	本章小结	15
第 2 章	数学分析	16
2.1	数列、级数与误差趋零	16
2.2	距离、连续性与极值存在	18
2.3	导数与线性近似	21
2.4	向量值函数与链式法则	23
2.5	二阶导数与曲率	25
2.6	积分与平均	27
2.7	坐标变换及其积分应用	31
2.8	极限与积分的交换	33
2.9	隐式求导与参数积分	36
2.10	非光滑与人为替代梯度	40
2.11	函数收敛与本质界	41
2.12	完备空间与压缩映射定理	43
2.13	本章小结	46
第 3 章	最优化	48
3.1	问题设定与解的性质	48

3.2	凸集与凸函数	50
3.3	较弱曲率与非凸结构	52
3.4	梯度下降与步长	53
3.5	曲率、加速与预条件	55
3.6	约束与拉格朗日乘子	58
3.7	原问题与对偶问题	61
3.8	松弛与最优性证书	64
3.9	非光滑目标与正则化	65
3.10	随机梯度与更新稳定性	67
3.11	分块、交替与分布优化	69
3.12	多目标与鞍点	71
3.13	双层目标与隐式更新	72
3.14	本章小结	74
第 4 章	泛函分析与逼近理论	76
4.1	函数作为空间中的对象	76
4.2	正交展开与函数投影	79
4.3	正定核与再生核空间	82
4.4	逼近能力与表示选择	87
4.5	函数类的大小与平滑性	90
4.6	函数类的组合与度量复杂度	93
4.7	序贯函数类与低秩分解	96
4.8	本章小结	98
第二部分	线性代数与几何	99
第 5 章	线性代数	100
5.1	向量空间与坐标	100
5.2	矩阵与线性映射	103
5.3	长度、角度与距离	107
5.4	正交投影与最小二乘	112
5.5	多维数组与结构运算	114
5.6	本章小结	119
第 6 章	矩阵分析	120
6.1	谱揭示矩阵沿哪些方向作用	120

6.2	奇异值分解连接几何、低秩与最小二乘	125
6.3	矩阵范数与有效秩	129
6.4	矩阵函数与结构化运算	132
6.5	条件数与扰动解释何时难以求准	137
6.6	稳定求解把结构转化为可靠计算	143
6.7	本章小结	146
第 7 章	微分几何与对称性	147
7.1	距离与坐标嵌入	148
7.2	流形与局部线性化	152
7.3	度量、路径与测地距离	154
7.4	平滑能量与几何算子	159
7.5	变换群、不变性与等变性	162
7.6	局部关系与拓扑信息	165
7.7	本章小结	168
第三部分	概率、随机过程与统计	171
第 8 章	概率论	172
8.1	概率空间与随机变量	172
8.2	绝对连续、密度与测度变换	175
8.3	联合、边缘与条件分布	178
8.4	期望、方差与条件期望	180
8.5	高阶矩、独立性与条件独立	185
8.6	常用分布与分布族	187
8.7	随机向量与分布变换	191
8.8	基础尾界、随机收敛与大样本近似	194
8.9	蒙特卡洛平均与方差控制	198
8.10	指数矩与集中不等式	202
8.11	多个对象与随机函数的联合误差	205
8.12	可交换性与有限样本秩	210
8.13	本章小结	212
第 9 章	随机过程与随机逼近	214
9.1	Markov 链与长期平均	214
9.2	简单鞅、停时与序贯集中	219

9.3	自归一化集中与自适应设计	224
9.4	随机逼近与 Markov 噪声	227
9.5	本章小结	234
第 10 章	数理统计	235
10.1	统计模型与推断目标	235
10.2	抽样制度与目标总体	237
10.3	似然、估计方程与稳健性	238
10.4	偏差、方差与估计效率	241
10.5	Bayes 估计与层次共享	245
10.6	区间、分位数与预测范围	246
10.7	假设检验与误差控制	249
10.8	重采样与经验不确定性	252
10.9	选择、多重比较与持续查看	254
10.10	概率预测、评分与校准	255
10.11	非参数估计与不完整观测	257
10.12	模型证据与局部积分近似	259
10.13	对照、预算与信息获取	262
10.14	本章小结	264
第 11 章	信息论与统计几何	265
11.1	不确定性与熵	265
11.2	预测分布与对数评分	269
11.3	分布差异的不同对象	273
11.4	换测度与信息控制	276
11.5	信息论下界与难以区分的模型	280
11.6	最优传输与分布距离	283
11.7	Fisher 几何与自然梯度	286
11.8	变分表达与概率学习	289
11.9	本章小结	292
第 12 章	因果推断	294
12.1	观测关联与生成结构	294
12.2	干预与潜在结果	299
12.3	因果效应的识别条件	301
12.4	部分识别与敏感性分析	305

12.5	反事实与行动补救	309
12.6	结构发现与假设检验	312
12.7	本章小结	315

第四部分	离散数学与图论	317
-------------	----------------	------------

第 13 章	组合数学	318
13.1	集合族与组合计数	318
13.2	逻辑与约束推理	323
13.3	组合优化与次模性	326
13.4	可计算性与复杂度	331
13.5	本章小结	335
第 14 章	图论	336
14.1	图的对象与表示	337
14.2	遍历、分离与结构分解	341
14.3	分配律与动态规划的代数	346
14.4	图上的精确与近似求解	352
14.5	图谱与离散对称性	358
14.6	本章小结	366

第五部分	动力系统、控制与决策	367
-------------	-------------------	------------

第 15 章	信号分析	368
15.1	离散信号与线性滤波	368
15.2	多项式乘法、求值与余数	372
15.3	复指数与频率表示	374
15.4	卷积定理与快速变换	377
15.5	采样与信息损失	383
15.6	图信号与状态核	388
15.7	本章小结	392
第 16 章	动力系统与状态估计	394
16.1	差分方程与常微分方程	394
16.2	离散化与递推组合	399
16.3	稳定性与敏感性	402
16.4	随机状态与观测模型	408

16.5	预测、滤波与平滑	410
16.6	平均动力学与线性随机递推	415
16.7	连续时间噪声与布朗运动	418
16.8	随机微分与密度演化	420
16.9	Hamilton 动力学与几何积分	426
16.10	本章小结	429
第 17 章	决策理论与动态风险	431
17.1	损失与 Bayes 决策	431
17.2	风险准则与鲁棒要求	435
17.3	序贯策略与动态规划	439
17.4	信息价值与探索	446
17.5	条件风险、动态递推与时间一致性	449
17.6	本章小结	453
第 18 章	控制理论	455
18.1	反馈与系统结构	455
18.2	线性二次控制与 Riccati 方程	462
18.3	安全不变集与控制屏障函数	468
18.4	动态优化与连续控制	473
18.5	本章小结	478
第 19 章	博弈论与多方决策	480
19.1	矩阵博弈与零和对偶	480
19.2	最佳响应与均衡存在	485
19.3	扩展式博弈与信息结构	491
19.4	遗憾与反事实分解	495
19.5	信用分配与多方收益	503
19.6	本章小结	508
第 20 章	数学基础与后续研究	509
20.1	学习理论与泛化	509
20.2	经典模型、核方法与几何表示	512
20.3	神经网络的结构与表示	515
20.4	神经网络的训练与泛化	517
20.5	概率模型的推断、学习与生成	520

20.6	可信机器学习	524
20.7	强化学习与序贯决策	527
20.8	知识的获取与融合	532
20.9	知识的演进与迁移	534
20.10	本章小结	537
参考文献		538
索引		543

第一部分

数学语言、分析与最优化

Mathematical Language, Analysis and Optimization

集合、函数与证明

机器学习中的公式往往写得很短。例如，给定样本 $(\mathbf{x}_i, y_i) \in \mathbb{R}^d \times \mathbb{R}$ ，其中 $i = 1, \dots, n$ ，并取正则化系数 $\lambda \geq 0$ ，一个带正则项的最小二乘问题可以写成

$$\min_{\mathbf{w} \in \mathbb{R}^d} F(\mathbf{w}) = \frac{1}{2n} \sum_{i=1}^n (\mathbf{w}^\top \mathbf{x}_i - y_i)^2 + \frac{\lambda}{2} \|\mathbf{w}\|_2^2. \quad (1.1)$$

其中 $\lambda = 0$ 对应不加正则项的情形。这行公式同时规定了候选参数、样本索引、目标函数和比较准则。若省略 $\mathbf{w} \in \mathbb{R}^d$ ，读者便不知道优化在哪个集合上进行；若不说明 λ 的范围，正则项可能鼓励参数变大而不是抑制参数；若把“存在一个参数对所有样本都预测正确”误写成“对每个样本都存在一个预测正确的参数”，结论甚至会完全改变。

本章把这些容易隐没在公式里的约定展开。集合说明对象从哪里取值，函数说明对象之间怎样对应，索引把一族对象组织起来，量词规定结论覆盖多大范围，证明则解释结论为何由条件推出。在这些语言之上，我们才能准确区分最优值、最优解、近似误差和计算代价。后续章节会增加分析、代数与概率工具，但它们都依赖本章建立的表达方式。

1.1 集合、关系与函数

1.1.1 从元素到结构

集合 (set) 把若干对象作为一个整体讨论。若对象 x 属于集合 X ，记作 $x \in X$ ；若 X 的每个元素也属于 Y ，记作 $X \subseteq Y$ 。空集记为 $\emptyset$ 。两个集合的并、交与差分别写作

$$X \cup Y, \quad X \cap Y, \quad X \setminus Y.$$

这些运算不仅整理对象，还能表达条件。例如，若 C 是满足资源约束的参数集合， D 是使模型有定义的参数集合，那么真正的可行域是 $C \cap D$ ，而不是其中任意一个集合。

集合的描述常有两种方式。列举法直接写出元素，如 $A = \{1, 2, 3\}$ ；条

件法写成

$$A = \{i \in \mathbb{N} : 1 \leq i \leq 3\}.$$

冒号右侧是成员必须满足的条件。集合只记录元素是否属于其中，不记录排列顺序，也不重复计数。因此 $\{1, 2, 3\}$ 、 $\{3, 2, 1\}$ 和 $\{1, 1, 2, 3\}$ 表示同一个集合。需要顺序或重复次数时，应使用序列、多重集合或向量，而不能继续依赖普通集合。

两个集合 X 与 Y 的**笛卡尔积** (Cartesian product) 是所有有序对组成的集合

$$X \times Y = \{(x, y) : x \in X, y \in Y\}.$$

“有序”意味着 (x, y) 与 (y, x) 通常不是同一个对象。一个带标签样本可以表示为 $(\mathbf{x}, y) \in \mathbb{R}^d \times \mathbb{R}$ ；包含 n 个样本的数据集则可以先看成该集合中的一个长度为 n 的序列。这样写清了一个样本的组成，却还没有对样本怎样产生作任何概率假设。

集合 X 上的**幂集** (power set) $\mathcal{P}(X)$ 由 X 的全部子集组成。如果 $X = \{a, b\}$ ，那么

$$\mathcal{P}(X) = \{\emptyset, \{a\}, \{b\}, \{a, b\}\}.$$

幂集在后文有两类用途。在概率模型中，事件是样本空间 Ω 的子集；实际允许赋予概率的事件通常只组成 $\mathcal{P}(\Omega)$ 的一个结构化子族，有限或可数离散样本空间中常取完整幂集。幂集也可以描述算法可能选择的特征子集或边集合。并非每次出现“若干子集”都需要完整幂集；允许的子集受到结构限制时，应另写一个集合族。概率事件族需要满足的闭包条件将在概率论部分说明。

1.1.2 关系把对象联系起来

集合 X 与 Y 之间的**二元关系** (binary relation) 是 $X \times Y$ 的一个子集 R 。写 xRy 表示 $(x, y) \in R$ 。关系允许一个 x 对应多个 y ，也允许没有对应对象。例如，“不大于”是 $\mathbb{R}$ 上的关系，“样本 i 与样本 j 之间有边”是索引集合上的关系。

定义在同一个集合 X 上的关系若满足

- 对每个 $x \in X$ 都有 xRx ；
- xRy 蕴含 yRx ；
- xRy 且 yRz 蕴含 xRz ，

就称为**等价关系** (equivalence relation)。三条性质分别称为自反性、对称性与传递性。等价关系把 X 分成互不相交的**等价类** (equivalence class)。例如，在 $\mathbb{R}^2 \setminus \{\mathbf{0}\}$ 上规定 $\mathbf{x} \sim \mathbf{y}$ 当且仅当存在 $c \in \mathbb{R} \setminus \{0\}$ 使 $\mathbf{x} = c\mathbf{y}$ ，那么

同一条过原点直线上的非零向量属于同一个等价类。后文讨论参数不可识别时，不同参数也可能因为产生同一个可观测对象而落入同一等价类。

偏序关系 (partial order) 也要求自反性与传递性，但把对称性换成反对称性： xRy 且 yRx 时必须有 $x = y$ 。集合包含关系 $\subseteq$ 就是偏序。偏序中的两个元素未必可比较，例如 $\{1\}$ 和 $\{2\}$ 都不是对方的子集。这一点会在多目标优化中再次出现：两个方案可能各自在一个目标上更好，因而不能排成一条总的优劣顺序。

1.1.3 函数、复合与逆

函数 (function) $f : X \rightarrow Y$ 为每个 $x \in X$ 指定唯一的 $f(x) \in Y$ 。 X 称为定义域， Y 称为陪域。函数在定义域上的实际输出组成

$$f(X) = \{f(x) : x \in X\},$$

称为像。陪域是函数定义的一部分，像则由函数实际取到的值决定，二者不必相等。例如 $f : \mathbb{R} \rightarrow \mathbb{R}$ 、 $f(x) = x^2$ 的像是 $[0, \infty)$ 。给定 $B \subseteq Y$ ，集合

$$f^{-1}(B) = \{x \in X : f(x) \in B\}$$

称为 B 在 f 下的**原像** (preimage)。这里的 $f^{-1}(B)$ 只表示满足输出条件的输入集合，即使 f 没有逆函数也有定义；它不能与后文双射的逆函数混为一谈。

必须区分函数 f 、输入 x 与函数值 $f(x)$ 。式 (1.1) 中的 F 是把每个参数向量映射到一个实数的函数， $F(\mathbf{w})$ 才是参数 $\mathbf{w}$ 对应的目标值。若要讨论一组候选函数，应把它们写成函数集合，例如

$$f_{\mathbf{w}} : \mathbb{R}^d \rightarrow \mathbb{R}, \quad f_{\mathbf{w}}(\mathbf{x}) = \mathbf{w}^\top \mathbf{x}, \quad \mathcal{F} = \{f_{\mathbf{w}} : \mathbf{w} \in \mathbb{R}^d\}.$$

这里 $\mathbf{w}$ 索引函数， $\mathbf{x}$ 是函数的输入。混淆这两个角色，会使“优化参数”和“对新输入求值”看起来像同一步操作。更准确地说，参数化给出了映射 $\mathbf{w} \mapsto f_{\mathbf{w}}$ 。它的输入是参数向量，输出却是一个函数，而不是这个函数在某个固定输入上的函数值；这里的函数值是标量。这个映射若不是单射，不同参数就会表示同一个函数；因此参数集合与由它表示的函数集合也不能直接视为同一个集合。

函数 $f : X \rightarrow Y$ 若满足 $f(x_1) = f(x_2)$ 必然推出 $x_1 = x_2$ ，就称为**单射** (injective function)；它不会把两个不同输入压成同一个输出。若每个 $y \in Y$ 都能写成 $f(x)$ ，就称为**满射** (surjective function)；它覆盖整个陪域。同时为单射和满射的函数称为双射。只有双射才存在定义在整个 Y 上

的逆函数 $f^{-1} : Y \rightarrow X$ ，并满足

$$f^{-1}(f(x)) = x, \quad f(f^{-1}(y)) = y.$$

若 f 只是单射，可以在像 $f(X)$ 上定义逆；若 f 不是单射，同一个输出对应多个输入，所谓“反求参数”便需要额外约束或只能返回一个集合。

给定 $f : X \rightarrow Y$ 与 $g : Y \rightarrow Z$ ，它们的**复合**（composition）是

$$(g \circ f)(x) = g(f(x)).$$

复合次序不能任意交换，因为 $g \circ f$ 与 $f \circ g$ 的定义域可能不同，即使都能定义，结果也通常不同。机器学习模型常由多层变换复合而成；检查每层输入输出的集合或维度，是发现公式错误的一种直接方法。再给定 $h : Z \rightarrow U$ ，复合满足结合律：

$$h \circ (g \circ f) = (h \circ g) \circ f.$$

恒等映射 $\text{id}_X(x) = x$ 不改变输入，并满足 $f \circ \text{id}_X = f$ 与 $\text{id}_Y \circ f = f$ 。若 f 与 g 均为双射，则 $g \circ f$ 也是双射，且 $(g \circ f)^{-1} = f^{-1} \circ g^{-1}$ ；逆映射的次序与原复合次序相反。

示例 1.1 参数不同而函数相同 考虑参数化函数

$$f_{a,b} : \mathbb{R} \rightarrow \mathbb{R}, \quad f_{a,b}(x) = abx, \quad (a,b) \in \mathbb{R}^2.$$

参数 $(1,2)$ 与 $(2,1)$ 不同，却对每个 x 给出相同的函数值。更一般地，只要 $c \neq 0$ ， $(ca, b/c)$ 与 (a,b) 表示同一个函数。由于定义域包含非零输入，例如取 $x = 1$ ，从完整的输入输出关系可以确定乘积 ab ，却不能分别确定 a 和 b 。这是参数化的不可识别性，而不是计算精度不足。

1.2 索引、有限和与递推

1.2.1 同一个下标可能承担不同角色

索引把一族对象排成可引用的形式。本书通常用 i, j, k 标识元素或样本，用 n 表示样本数，用 d 表示特征维数，用带括号的上标 t 表示迭代步。例如， $\mathbf{x}_i \in \mathbb{R}^d$ 是第 i 个样本， $x_{i,j}$ 是该样本的第 j 个坐标， $\mathbf{w}^{(t)}$ 是第 t 次迭代的参数。普通上标则保留给幂： w_j^2 表示平方，而 $w_j^{(2)}$ 表示第 2 次迭代中的第 j 个坐标。若对象本身按时间排列，还应另行声明时间下标，例如 $\mathbf{z}_\tau$ 表示时刻 τ 的状态。样本编号、物理时间和算法迭代都可以取整数值，但它们索引的是不同对象，不能仅因数值相同就互换。

下标只有在取值范围明确时才有意义。写

$$\sum_{i=1}^n a_i$$

表示把 $a_1, \dots, a_n$ 相加, 其中 i 是求和过程中变化的**哑索引** (dummy index)。把 i 换成 k 不会改变结果。与之不同, 等式

$$b_j = \sum_{i=1}^n x_{i,j}$$

中的 j 是自由索引: 等式对哪些 j 成立需要在附近说明, 而且改变 j 会选取不同坐标。同一个符号不能在一项中既作哑索引又作自由索引。

双重求和需要同时写清两个范围。对有限数组 $a_{i,j}$,

$$\sum_{i=1}^n \sum_{j=1}^d a_{i,j} = \sum_{j=1}^d \sum_{i=1}^n a_{i,j},$$

因为两边都遍历同一个有限索引集 $\{1, \dots, n\} \times \{1, \dots, d\}$, 并把每个索引对 (i, j) 对应的项 $a_{i,j}$ 恰好相加一次。后文把有限和换成无限级数或积分时, 交换次序将需要额外条件, 不能直接沿用这个有限情形的结论。

1.2.2 有限和、乘积与加权平均

有限和满足线性关系。对标量 a, b 与同长度序列 $(u_i), (v_i)$,

$$\sum_{i=1}^n (au_i + bv_i) = a \sum_{i=1}^n u_i + b \sum_{i=1}^n v_i.$$

若权重 $\alpha_i \geq 0$ 且 $\sum_{i=1}^n \alpha_i = 1$, 则 $\sum_i \alpha_i u_i$ 称为有限**加权平均** (weighted average)。普通样本平均对应 $\alpha_i = 1/n$ 。这个简单对象会成为积分与期望的有限版本: 积分允许位置形成连续集合, 期望则按概率分配权重。

有限乘积写作 $\prod_{i=1}^n a_i$ 。按照空操作不改变结果的约定,

$$\sum_{i \in \emptyset} a_i = 0, \quad \prod_{i \in \emptyset} a_i = 1.$$

这两个约定分别把 0 和 1 作为加法与乘法的单位元, 使递推公式在边界处仍可保持统一。使用乘积前仍应检查零因子与符号; 对正数取对数可把乘积变成和, 但含零或负数时不能直接这样做。

1.2.3 递推式描述状态怎样更新

递推 (recurrence) 用当前或过去的值定义后续值。仅写更新规则还不够,

必须同时给出初值。例如

$$e^{(t+1)} = \rho e^{(t)}, \quad e^{(0)} = e_0, \quad (1.2)$$

逐步展开得到

$$e^{(t)} = \rho^t e_0.$$

当 $|\rho| < 1$ 时, 误差绝对值按几何速度缩小; $\rho = -1$ 时大小不变而符号交替; $|\rho| > 1$ 时则放大。因而“反复执行更新”本身不保证收敛, 更新系数的范围才决定长期行为。

更一般的误差递推

$$e^{(t+1)} \leq \rho e^{(t)} + \delta_t, \quad 0 \leq \rho < 1, \quad (1.3)$$

包含每一步的扰动 δ_t 。连续展开 t 步可得

$$e^{(t)} \leq \rho^t e^{(0)} + \sum_{s=0}^{t-1} \rho^{t-1-s} \delta_s. \quad (1.4)$$

第一项是初始误差的衰减, 第二项是历次扰动经过不同程度衰减后的累计。只说明 δ_t 很小, 仍不足以断言累计项趋于零; 还要检查扰动是否趋零、是否可求和, 以及几何权重怎样作用于它。

式 (1.4) 可以用数学归纳法证明: 先核对 $t = 1$ 的基例, 再假设结论对 t 成立并据此推出 $t + 1$ 时的结论。完整证明将在本章介绍归纳法时给出。

1.2.4 计数公式说明候选有多少

从 n 个不同对象中依次取出 k 个且不放回, 若顺序重要, 可得到

$$P(n, k) = n(n-1) \cdots (n-k+1) = \frac{n!}{(n-k)!}$$

种排列。若只关心选中了哪些对象, 不关心次序, 每个大小为 k 的子集被计算了 $k!$ 次, 因此组合数为

$$\binom{n}{k} = \frac{n!}{k!(n-k)!}, \quad 0 \leq k \leq n. \quad (1.5)$$

规定 $\binom{n}{k} = 0$ 用于 $k < 0$ 或 $k > n$, 可以统一许多边界公式。

把 n 个对象的子集按是否包含某个固定对象分组, 可得 Pascal 恒等式

$$\binom{n}{k} = \binom{n-1}{k} + \binom{n-1}{k-1}.$$

第一项计算不包含固定对象的子集, 第二项先包含该对象, 再从其余 $n-1$ 个对象中选择 $k-1$ 个。这种“为同一集合建立不重不漏的两种计数”称

为组合证明。后文的组合数学章会系统讨论计数、生成函数与离散结构；这里保留最常用的公式与论证方式。

二项式定理把组合数与代数展开连接起来：

$$(a+b)^n = \sum_{k=0}^n \binom{n}{k} a^k b^{n-k}. \quad (1.6)$$

选择展开式中的一项时，需要从 n 个因子中挑出 k 个贡献 a ，其余贡献 b ，所以 $a^k b^{n-k}$ 前的系数正是 $\binom{n}{k}$ 。概率论中的二项分布和学习理论中的有限类计数都会复用这个关系。

1.3 命题、量词与条件

1.3.1 命题必须能够判断真假

命题 (proposition) 是能够判定真假的陈述。“ F 有最小值”是命题，“求 F 的最小值”则是任务。带变量的表达式如 “ $x^2 \geq 0$ ” 还需要说明 x 的取值范围或添加量词，才成为完整命题。对实数它成立，对复数若使用通常的序关系则没有定义。

命题 P 的否定记为 $\neg P$ 。两个命题的“且”“或”分别记为 $P \wedge Q$ 和 $P \vee Q$ 。数学中的“或”通常是可兼容的： P 和 Q 同时为真时， $P \vee Q$ 仍为真。若只允许恰有一个成立，需要明确写成异或条件。

蕴含 (implication) $P \Rightarrow Q$ 表示只要 P 为真， Q 就必须为真。这里 P 是 Q 的充分条件， Q 是 P 的必要条件。反向命题 $Q \Rightarrow P$ 需要单独证明。两向都成立时写作 $P \Leftrightarrow Q$ ，称为等价条件。

定理中的假设正是在限定 P 所覆盖的对象。例如，“目标函数连续且可行域紧致”只允许把结论用于同时满足这两个条件的问题，不能从定理名称中删去其中一个条件。类似地，“存在一个最优解”是 $\exists x^* \in X$ 开头的命题，而“每个初值产生的迭代都收敛”是 $\forall x^{(0)} \in X$ 开头的另一命题；前者成立并不自动给出后者。

以实数 x 为例， $x > 1$ 是 $x^2 > 1$ 的充分条件，却不是必要条件，因为 $x < -1$ 时也有 $x^2 > 1$ 。条件 $x \neq 0$ 是 $x^2 > 0$ 的充分必要条件。把充分条件误当作必要条件，会排除本来可能成立的情形；把必要条件误当作充分条件，则可能把不合格对象当成解。

1.3.2 全称与存在量词规定保证范围

全称量词 (universal quantifier) $\forall$ 表示“对每一个”，**存在量词** (existential

quantifier) $\exists$ 表示“至少存在一个”。例如

$$\forall x \in \mathbb{R}, \quad x^2 \geq 0$$

是全称命题，而

$$\exists x \in \mathbb{R}, \quad x^2 = 2$$

是存在命题。存在并不表示唯一；要表达恰有一个对象满足条件，可以写 $\exists!x$ ，但使用时仍应说明存在性与唯一性各由什么保证。

否定量词时，量词种类与内部命题同时改变：

$$\neg(\forall x \in X, P(x)) \iff \exists x \in X, \neg P(x),$$

$$\neg(\exists x \in X, P(x)) \iff \forall x \in X, \neg P(x).$$

所以，要推翻“每个输入都满足性质 P ”，找到一个不满足的输入即可；要证明“没有输入满足 P ”，则必须排除所有输入。

1.3.3 量词次序不能交换

考虑样本集合 $S = \{1, \dots, n\}$ 和参数集合 W ，令 $C(w, i)$ 表示参数 w 在第 i 个样本上预测正确。陈述

$$\exists w \in W, \quad \forall i \in S, \quad C(w, i) \tag{1.7}$$

要求找到同一个参数，使它对所有样本都正确。陈述

$$\forall i \in S, \quad \exists w \in W, \quad C(w, i) \tag{1.8}$$

却允许参数随样本改变，因而弱得多。

示例 1.2 逐点可选不等于统一可选 令 $S = W = \{0, 1\}$ ，并规定 $C(w, i)$ 当且仅当 $w = i$ 。对每个 i ，选择 $w = i$ 即可，所以式 (1.8) 成立。但不存在一个 w 同时等于 0 和 1，所以式 (1.7) 不成立。

例 1.2 说明，量词次序改变了允许依赖哪些信息。统计学习中的“对每个允许分布，以高概率得到小误差”也包含多个量词；算法、样本量和失败概率是否可以依赖分布，必须由量词位置决定，不能靠自然语言猜测。

1.3.4 量词也规定误差界是否统一

设 $f_n : X \rightarrow \mathbb{R}$ 是一列函数， $f : X \rightarrow \mathbb{R}$ 。陈述

$$\forall x \in X, \quad \forall \varepsilon > 0, \quad \exists N = N(x, \varepsilon), \quad \forall n \geq N, \quad |f_n(x) - f(x)| < \varepsilon$$

允许所需的 N 依赖 x , 描述逐点收敛。若把 $\exists N$ 移到 $\forall x$ 之前,

$$\forall \varepsilon > 0, \quad \exists N = N(\varepsilon), \quad \forall x \in X, \quad \forall n \geq N, \quad |f_n(x) - f(x)| < \varepsilon,$$

同一个 N 必须同时控制所有 x , 这就是更强的一致收敛。第2章会用具体函数序列比较两者。这里应先看到, 区别不在“趋近”这个词, 而在误差阈值之后允许谁依赖谁。

1.4 证明、构造与反例

1.4.1 证明把条件连接到结论

证明不是把若干正确公式排列在一起, 而是从已给条件出发, 经过每一步都合法的推理到达结论。开始证明前, 先辨认命题的逻辑形式。对 $P \Rightarrow Q$, 直接证明从 P 出发; 逆否证明改证 $\neg Q \Rightarrow \neg P$; 反证法假设 P 成立而 Q 不成立, 并推出矛盾。这些形式在逻辑上等价, 但哪一种更清楚取决于条件怎样进入计算¹。

定理 1.3 严格中点条件保证至多一个最小点 设 $C \subseteq \mathbb{R}^d$ 满足: 任取 $\mathbf{u}, \mathbf{v} \in C$, 其中点 $(\mathbf{u} + \mathbf{v})/2$ 仍属于 C 。若函数 $F : C \rightarrow \mathbb{R}$ 对任意不同的 $\mathbf{u}, \mathbf{v} \in C$ 都满足

$$F\left(\frac{\mathbf{u} + \mathbf{v}}{2}\right) < \frac{F(\mathbf{u}) + F(\mathbf{v})}{2}, \quad (1.9)$$

那么 F 在 C 上至多有一个最小点。

¹ R. L. Graham, D. E. Knuth, O. Patashnik, *Concrete Mathematics: A Foundation for Computer Science*, Addison-Wesley, 1994, 2nd ed.

证明. 证明的关键是: 若有两个不同的最小点, 它们的中点会给出更小的函数值。为此反设 $\mathbf{u} \neq \mathbf{v}$ 都是最小点, 并把共同的最小值记为 m 。由 C 对取中点封闭, $(\mathbf{u} + \mathbf{v})/2 \in C$ 。再由式 (1.9),

$$F\left(\frac{\mathbf{u} + \mathbf{v}}{2}\right) < \frac{m + m}{2} = m.$$

这与 m 是最小值矛盾, 所以不可能存在两个不同的最小点。 ■

定理 1.3 只证明“至多一个”, 没有证明最小点存在。函数可以满足排除两个最小点的条件, 却根本没有最小点。第3章会把中点条件扩展为凸性, 并分别建立存在条件与唯一条件。

1.4.2 构造证明需要给出可检验的对象

存在命题 $\exists x \in X, P(x)$ 可以通过构造一个具体 x 并核对 $P(x)$ 来证明。例如, 要证明对任意 $a, b \in \mathbb{R}$ 且 $a < b$, 存在 c 满足 $a < c < b$, 可以取

$c = (a + b)/2$ 。由 $a < b$ 分别加上 a 与 b ，再除以正数 2，得到

$$a < \frac{a+b}{2} < b.$$

构造不仅说明对象存在，还可能给出计算它的方法。

但存在性与可构造性不是同一个逻辑要求。某些证明通过排除“不存在”的可能来确认对象存在，却不提供有限步骤找到该对象。反过来，一个算法给出候选对象，也仍要证明它终止并满足条件。后文谈“最优解存在”和“算法收敛”时，会分别承担这两项责任。

1.4.3 归纳法处理按整数扩展的命题

数学归纳法适合证明由整数 n 索引的一族命题 $P(n)$ 。它包括基例和归纳步：先证明 $P(n_0)$ ，再证明对每个 $n \geq n_0$ ， $P(n)$ 蕴含 $P(n+1)$ 。这两步共同覆盖所有 $n \geq n_0$ ，不能只展示几个数值例子。

回到式 (1.4)，它对每个整数 $t \geq 1$ 给出同一种误差界，正适合用归纳法验证。

式 (1.4) 的归纳证明。当 $t = 1$ 时，式 (1.3) 正是所需结论。假设结论对 t 成立，再使用一次递推式，得到

$$\begin{aligned} e^{(t+1)} &\leq \rho e^{(t)} + \delta_t \\ &\leq \rho^{t+1} e^{(0)} + \sum_{s=0}^{t-1} \rho^{t-s} \delta_s + \delta_t \\ &= \rho^{t+1} e^{(0)} + \sum_{s=0}^t \rho^{t-s} \delta_s. \end{aligned}$$

这就是把 t 换成 $t+1$ 后的式子，归纳完成。 ■

定理 1.4 前 n 个正整数之和 对每个 $n \in \mathbb{N}$ 且 $n \geq 1$,

$$\sum_{i=1}^n i = \frac{n(n+1)}{2}.$$

证明。当 $n = 1$ 时，两边都等于 1。假设公式对某个 $n \geq 1$ 成立，则

$$\sum_{i=1}^{n+1} i = \left(\sum_{i=1}^n i \right) + (n+1) = \frac{n(n+1)}{2} + (n+1) = \frac{(n+1)(n+2)}{2}.$$

这正是 $n+1$ 时的公式，故结论对所有 $n \geq 1$ 成立。 ■

归纳假设只能用于已经假设的 $P(n)$ ，不能把待证的 $P(n+1)$ 换一种说法后当作依据。若递推依赖前两个状态，则归纳假设和基例也要覆盖相应数量的前项。

1.4.4 反例确定结论的边界

一个全称命题声称所有允许对象都满足某种性质，所以一个合法反例就足以推翻它。反例必须满足原命题的前提而违反结论；若它同时违反前提，只能说明例子不在讨论范围内。

例如，“目标函数有下界就一定达到最小值”是错误的。取

$$X = (0, 1), \quad f(x) = x.$$

$f(x) > 0$ ，所以 0 是下界；而对每个 $x \in (0, 1)$ ， $x/2$ 仍在 $(0, 1)$ 中且 $f(x/2) < f(x)$ ，所以没有任何 x 达到最小值。失败原因不是函数不连续，而是定义域没有包含趋近边界时的极限点。第 2 章会用闭性、紧致性和连续性给出保证极值达到的条件。

反例也能区分相近概念。一个参数化不是单射，说明参数未必可识别；它不说明预测函数一定不能确定。一次迭代使目标下降，说明当前步骤有效；它不说明所有迭代都会收敛到全局最优。把结论限制到证据真正覆盖的对象，是证明工作的一部分。

1.5 最优值与误差表达

1.5.1 最小值与下确界

设 X 非空且 $f : X \rightarrow \mathbb{R}$ 。若 $x^* \in X$ 满足

$$\forall x \in X, \quad f(x^*) \leq f(x),$$

则 x^* 是一个**全局最小点** (global minimizer)， $f(x^*)$ 是最小值。所有最小点组成

$$\arg \min_{x \in X} f(x) = \{x \in X : f(x) = \min_{z \in X} f(z)\}.$$

$\arg \min$ 返回集合，而 $\min$ 返回数值。最小点不唯一时， $\arg \min$ 包含多个元素；最小值未达到时， $\min$ 和 $\arg \min$ 都不能按上式使用。

即使没有最小值，只要 $f(X)$ 有下界，仍可定义**下确界** (infimum)

$$f^* = \inf_{x \in X} f(x).$$

f^* 是 $f(X)$ 的最大下界：每个 $f(x)$ 都不小于 f^* ，并且任何更大的数都不再是下界。前面的 $f(x) = x$ 、 $X = (0, 1)$ 满足 $\inf_{x \in X} f(x) = 0$ ，但不存在

$x \in X$ 使 $f(x) = 0$ 。

与下界对称, 若 $f(X)$ 有上界, 则它的最小上界称为**上确界** (supremum), 记为

$$\sup_{x \in X} f(x).$$

若某个 $x^* \in X$ 达到这个数值, 便得到最大值和最大点。下确界、上确界描述可逼近的边界, 最小值、最大值则额外要求边界由定义域中的元素达到。若 f 无下界, 约定 $\inf_{x \in X} f(x) = -\infty$; 若 f 无上界, 则相应上确界为 $+\infty$ 。

给定 $\varepsilon > 0$, 若

$$f(\hat{x}) \leq \inf_{x \in X} f(x) + \varepsilon, \quad (1.10)$$

则称 $\hat{x}$ 为 ε -**近似最优解** (approximately optimal solution)。只要下确界有限, 这样的点对每个 $\varepsilon > 0$ 都存在; 否则 $f^* + \varepsilon$ 仍会是一个严格大于下确界的下界, 与下确界的定义矛盾。近似最优描述的是目标值差距, 不自动保证 $\hat{x}$ 接近某个最小点。要把目标误差换成参数距离, 还需要曲率等额外条件。

式 (1.10) 只适用于有限下确界。若 $\inf_{x \in X} f(x) = -\infty$, 右侧不是可比较的有限误差阈值; 此时应寻找一个序列 (x_k) 使 $f(x_k) \rightarrow -\infty$ 。例如, 可以对每个正整数 k 选取满足 $f(x_k) \leq -k$ 的点。这样的序列说明目标值可以任意降低, 却不提供一个取值为 $-\infty$ 的“最小点”。

同一近似参数还可以用不同误差衡量。对式 (1.1), 令 $F^* = \inf_{\mathbf{w} \in \mathbb{R}^d} F(\mathbf{w})$; 若选定一个最小点 $\mathbf{w}^*$, 则

$$F(\hat{\mathbf{w}}) - F^*, \quad \|\hat{\mathbf{w}} - \mathbf{w}^*\|_2, \quad \left(\frac{1}{n} \sum_{i=1}^n (\hat{\mathbf{w}}^\top \mathbf{x}_i - (\mathbf{w}^*)^\top \mathbf{x}_i)^2 \right)^{1/2}$$

分别是目标值误差、参数误差和在给定样本输入上的预测误差。最小点不唯一时, 参数误差还需要指定参照解, 或改成到最小点集合的距离。三种误差衡量不同对象, 彼此能否控制取决于目标曲率、数据矩阵和参数化; 一个误差较小不能无条件推出另两个也较小。

1.5.2 大 O、小 o 与比较尺度

算法和估计误差常随规模变化。设 a_n 与 b_n 为实数序列, 且从某个位置开始 $b_n > 0$ 。若存在常数 $C > 0$ 和 n_0 , 使得

$$\forall n \geq n_0, \quad |a_n| \leq C b_n,$$

则记 $a_n = O(b_n)$ 。这表示 a_n 的绝对值最终被 b_n 的常数倍控制，常数 C 不随 n 改变。若

$$\lim_{n \rightarrow \infty} \frac{a_n}{b_n} = 0,$$

则记 $a_n = o(b_n)$ ，表示 a_n 相对于 b_n 可以忽略。

例如 $n = O(n)$ 、 $3n + 7 = O(n)$ 且 $\log n = o(n)$ 。但大 O 不是精确等式： $n = O(n^2)$ 也成立，只是界较松。写算法复杂度时还要说明被计数的操作、输入规模和计算模型；写统计误差时则要说明界是确定性的、期望意义的还是以高概率成立²。

当序列还依赖维数 d 或其他规模时，也要说明哪些量允许进入隐含常数。例如，对每个固定 d 都有 $d/n = O(1/n)$ ，因为可以取 $C = d$ ；但若要求同一个 C 同时适用于任意 d ，这个界就不成立。因此，“关于 n 是某个速率”不等于该速率对维数一致。需要一致结论时，应把量词写成对所讨论的全部 d 使用同一组 C 与 n_0 ，或把 d 显式保留在界中。

对迭代序列，常用 t 而不是 n 表示步数。例如

$$F(\mathbf{w}^{(t)}) - F^* = O(1/t)$$

表示存在与 t 无关的常数控制目标值误差。这个式子没有说明参数误差 $\|\mathbf{w}^{(t)} - \mathbf{w}^*\|_2$ 具有同样速率，也没有说明一次迭代的成本。比较算法时，必须固定误差对象和成本口径。

1.5.3 四类问题不能由一个最优公式代替

式 (1.1) 看似只要求“求一个最小值”，实际包含四类不同问题。

问题	需要回答的内容
存在性	是否有 $\mathbf{w}^*$ 真正达到 $\inf_{\mathbf{w}} F(\mathbf{w})$ 。
唯一性	达到最优值的参数是否只有一个。
可识别性	不同参数是否会产生相同的可观测预测或数据分布。
可计算性	是否存在在给定资源与精度下找到解或近似解的步骤。

表 1.1 最优化陈述中的四类不同要求。每一行需要不同的条件与论证。

这四类问题彼此相关，却不能相互替代。一个有限非空候选集上的函数必定达到最小值，但若没有给出枚举候选或计算函数值的有效方式，存在性本身不提供实际算法。例 1.1 中的参数不可唯一识别，但乘积 ab 对应的预测函数仍可唯一确定。反过来，即使目标函数只有一个最小点，有限精度计算通常也只能返回近似值；能否精确到达该点，或能在多大误差内逼近它，需要单独的算法保证。

回到带正则项的最小二乘。它的变量属于 $\mathbb{R}^d$ ，目标值属于 $\mathbb{R}$ ，样本索引 i 遍历同一组 n 个观测， λ 控制第二项的权重。若要声称某算法返回唯

² R. L. Graham, D. E. Knuth, O. Patashnik, *Concrete Mathematics: A Foundation for Computer Science*, Addison-Wesley, 1994, 2nd ed.

一的目标最优点，需要分别证明最小点存在、最小点唯一，以及算法确实到达该点；若算法只给出误差保证，则应改称它在规定成本下得到近似解。只有进一步声称该参数可由观测唯一确定，或算法恢复了真实参数时，才需要额外证明数据与参数化具有所需的可识别性。后续章节将在各自需要时分别给出这些条件。

1.6 本章小结

一个数学结论由对象、范围、条件和保证共同组成。集合与函数规定讨论什么，索引与递推规定一族量怎样组织，量词决定选择能依赖哪些对象，证明则把条件逐步连接到结论。改变定义域、交换量词或混淆充分条件与必要条件，都可能把原命题换成另一个命题。

最优化问题尤其需要分层判断。下确界只描述能够逼近的最佳数值，最小点还要求该数值被达到；唯一性排除多个最小点，可识别性排除观测等价的参数，而可计算性要求给出能够在资源限制内执行的过程。大 O 、小 o 与近似最优条件分别说明量的尺度上界、给定趋向下的相对变化和目標值容差，不能一概理解为误差随规模缩小。第 2 章将沿用这些语言，研究极限、连续性、微分与积分各在什么条件下成立。

数学分析

第1章说明了怎样写清对象、条件与保证。本章进一步追问：当计算过程包含无限多步，或者函数需要在连续区域上取平均时，有限步骤中的代数规则还能否直接沿用？答案取决于极限。导数用极限描述函数在一点附近的变化，积分用极限汇总一个区域上的贡献，迭代算法也常以极限作为最终结果。极限存在并不意味着它能与求导、积分或另一重极限交换；每一种交换都需要相应的控制条件。

本章假定读者已经学过一元微积分和基本矩阵运算，从这些熟悉的计算出发补齐后续机器学习推导所需的条件。我们先研究数列与连续性，明确无限过程何时落到允许的空间中；随后把导数组织成局部线性映射，并建立向量和矩阵微分；再由有限加权和进入一般积分，分析换元、积分次序和参数求导。函数不光滑或函数列发生变化时，还必须说明控制的是函数值、导数、平均误差还是最坏输入误差。章末的压缩映射定理把这些线索收拢起来：它不仅保证迭代极限存在，还给出唯一性和可核对的误差界。

2.1 数列、级数与误差趋零

2.1.1 极限描述最终稳定到哪里

数列 (sequence) 是以自然数为索引的一族数，写作 $(a_n)_{n \geq 1}$ 。若对每个 $\varepsilon > 0$ ，都存在只依赖于 ε 的整数 N ，使得

$$n \geq N \implies |a_n - a| < \varepsilon,$$

就称 a_n **收敛** (converge) 到 a ，记作 $a_n \rightarrow a$ 。这一定义要求同一个 N 控制其后的全部项，而不是只要求数列偶尔靠近 a 。极限若存在便唯一：若 $a \neq b$ 都是极限，取 $\varepsilon = |a - b|/3$ ，充分靠后的 a_n 会同时落入两个不相交的邻域，产生矛盾。

收敛数列必有界。事实上，取 $\varepsilon = 1$ 后，除有限个前项外都有 $|a_n| \leq |a| + 1$ ，再把有限个前项的绝对值一并取最大值即可。反向结论通常不成立，例如 $a_n = (-1)^n$ 有界却不收敛。若再加入单调性，情况便不同。

这里需要使用实数的**完备性** (completeness)。它的一种等价表述是确界公理：每个非空且有上界的实数集合都有实数上确界。稍后讨论柯西数列时，还会看到完备性的另一种等价表述。

定理 2.1 单调有界收敛定理 若实数列 (a_n) 单调不减且有上界，则 a_n 收敛到 $a = \sup\{a_n : n \in \mathbb{N}\}$ 。单调不增且有下界的情形类似。

证明. 这里只证明单调不减的情形。集合 $\{a_n : n \in \mathbb{N}\}$ 非空且有上界，实数的完备性保证其上确界 a 存在。给定 $\varepsilon > 0$ ，数 $a - \varepsilon$ 不可能仍是上界，所以存在 N 使 $a_N > a - \varepsilon$ 。当 $n \geq N$ 时，单调性给出

$$a - \varepsilon < a_N \leq a_n \leq a,$$

从而 $|a_n - a| < \varepsilon$ 。这正是 $a_n \rightarrow a$ 。 ■

定理中的“有界”与“单调”缺一不可： n 单调却无上界， $(-1)^n$ 有界却不单调。证明还使用了实数的完备性；若只在有理数中考察逐步逼近 $\sqrt{2}$ 的有理数列，所有项都在有理数中，极限却不在这个空间中。第 2.12 节会把这种“柯西数列的极限仍留在空间内”的性质推广到一般度量空间。

2.1.2 柯西条件只比较数列内部

有时我们还不知道候选极限，却能证明后面的项彼此越来越近。**柯西数列** (Cauchy sequence) 满足

$$\forall \varepsilon > 0, \exists N, \forall m, n \geq N, |a_m - a_n| < \varepsilon.$$

每个收敛实数列都是柯西数列，因为 $|a_m - a_n| \leq |a_m - a| + |a_n - a|$ 。反过来，每个实柯西数列也收敛；这是实数完备性的等价表述之一。柯西条件的价值在于，它只使用已经算出的项，适合分析尚不知道极限为何物的迭代。

若能控制相邻差，还可以借助三角不等式验证柯西条件。对 $m > n$,

$$|a_m - a_n| \leq \sum_{k=n}^{m-1} |a_{k+1} - a_k|. \quad (2.1)$$

因此，只要相邻差的无穷级数收敛，其尾和就趋于零， (a_n) 必为柯西数列。章末证明压缩迭代收敛时，关键步骤正是把相邻迭代差控制成可求和的几何序列。

2.1.3 级数控制累计量

无穷级数 (infinite series) $\sum_{n=1}^{\infty} a_n$ 是否收敛, 是指部分和 $s_N = \sum_{n=1}^N a_n$ 是否有有限极限。级数收敛必然推出 $a_n = s_n - s_{n-1} \rightarrow 0$, 但单项趋零并不足够。例如调和级数 $\sum_{n=1}^{\infty} 1/n$ 发散。把从 2^k 到 $2^{k+1} - 1$ 的项分成一组, 该组有 2^k 项, 每项至少为 $1/2^{k+1}$, 所以每组之和至少为 $1/2$; 部分和因而可以超过任意给定常数。

当 $|r| < 1$ 时, 有限几何和

$$\sum_{n=0}^N r^n = \frac{1 - r^{N+1}}{1 - r}$$

在 $N \rightarrow \infty$ 时给出

$$\sum_{n=0}^{\infty} r^n = \frac{1}{1 - r}. \quad (2.2)$$

$|r| < 1$ 不可删去: $r = 1$ 时部分和不断增长, $r = -1$ 时部分和振荡, $|r| > 1$ 时单项甚至不趋于零。折扣回报和几何误差界都依赖这一条件。

若 $\sum_n |a_n| < \infty$, 就称级数**绝对收敛** (absolutely converge)。由式 (2.1) 对应的尾和估计, 绝对收敛蕴含收敛。绝对收敛还允许较自由地重新排列求和次序; 只有条件收敛时, 重排可能改变和甚至使其发散。第 2.8 节中的 Fubini 定理, 是这一原则在积分上的对应版本。

2.1.4 单步、累计与可求和误差

设第 t 步计算产生非负误差 δ_t 。“单步误差趋零”只表示 $\delta_t \rightarrow 0$; “前 T 步累计误差”是 $\sum_{t=0}^{T-1} \delta_t$; “误差可求和”则要求 $\sum_{t=0}^{\infty} \delta_t < \infty$ 。三者不能混用。例如 $\delta_t = 1/(t+1)$ 逐步趋零, 但累计误差无界; $\delta_t = 1/(t+1)^2$ 才可求和。若误差进入第 1 章式 (1.3) 那样的稳定递推, 较早误差还会被几何权重衰减, 此时应分析加权重累计量, 而不是只看 δ_t 本身。

步长序列也常同时承担“持续前进”和“抑制平方误差”两项职责。典型条件

$$\sum_{t=1}^{\infty} \alpha_t = \infty, \quad \sum_{t=1}^{\infty} \alpha_t^2 < \infty$$

可由 $\alpha_t = 1/t$ 满足: 第一项是调和级数, 第二项是收敛的 p 级数。这里尚不能据此推出随机算法收敛, 因为还缺少噪声和目标函数的条件; 这个例子只说明两个累计对象可以有不同结论。后续分析折扣、步长和扰动时, 都应先问清楚趋零的是哪一项、累计采用什么权重, 以及所需级数是否真的收敛。

2.2 距离、连续性与极值存在

2.2.1 距离把“靠近”推广到一般对象

实数上的绝对值能够衡量两点距离，但函数、概率分布或离散状态未必适合用绝对值比较。集合 X 上的**度量** (metric) 是函数 $d : X \times X \rightarrow [0, \infty)$ ，满足对任意 $x, y, z \in X$,

$$d(x, y) = 0 \iff x = y, \quad d(x, y) = d(y, x), \quad d(x, z) \leq d(x, y) + d(y, z).$$

带有度量的集合 (X, d) 称为**度量空间** (metric space)。欧氏空间使用 $d(\mathbf{x}, \mathbf{y}) = \|\mathbf{x} - \mathbf{y}\|_2$ ；有限集合可以使用离散度量 $d(x, y) = \mathbb{I}\{x \neq y\}$ 。同一个集合选择不同度量，会改变何谓收敛以及函数是否连续，所以讨论这些性质时必须说明所用距离。

以 $x \in X$ 为中心、半径 $r > 0$ 的开球记为 $B(x, r) = \{y \in X : d(x, y) < r\}$ 。数列 (x_n) 在 (X, d) 中收敛到 x ，是指

$$\forall \varepsilon > 0, \quad \exists N, \quad n \geq N \implies d(x_n, x) < \varepsilon;$$

等价地， $d(x_n, x) \rightarrow 0$ 。数列 (x_n) 称为柯西数列，是指

$$\forall \varepsilon > 0, \quad \exists N, \quad m, n \geq N \implies d(x_m, x_n) < \varepsilon.$$

这两条定义分别把实数中的 $|a_n - a|$ 与 $|a_m - a_n|$ 替换为一般距离。

集合 $U \subseteq X$ 若对每个 $x \in U$ 都包含某个开球 $B(x, r)$ ，就称为**开集** (open set)；集合 C 若其补集 $X \setminus C$ 为开集，就称为**闭集** (closed set)。闭集的一个实用判据是：若 C 中的任意收敛序列 $x_n \rightarrow x$ 都有 $x \in C$ ，则 C 闭。闭与有界描述不同性质；例如 $(0, 1)$ 有界但不闭， $\mathbb{R}$ 闭但不有限。

2.2.2 连续性保证小输入扰动只产生小输出扰动

设 (X, d_X) 与 (Y, d_Y) 为度量空间。函数 $f : X \rightarrow Y$ 在 $x \in X$ 处**连续** (continuous)，是指

$$\forall \varepsilon > 0, \quad \exists \delta > 0, \quad d_X(x, x') < \delta \implies d_Y(f(x), f(x')) < \varepsilon.$$

这里 δ 可以依赖 x 和 ε 。等价地，只要 $x_n \rightarrow x$ ，就有 $f(x_n) \rightarrow f(x)$ 。连续函数因而允许把一个已经存在的极限送入函数： $f(\lim_n x_n) = \lim_n f(x_n)$ 。

若对每个 $\varepsilon > 0$ 都能找到一个与具体位置无关的 $\delta > 0$ ，使任意 $x, x' \in X$ 只要 $d_X(x, x') < \delta$ 便有 $d_Y(f(x), f(x')) < \varepsilon$ ，就称 f **一致连续** (uniformly continuous)。连续性允许不同位置使用不同的 δ ，一致连续则要求同一个 δ 同时控制整个定义域。连续函数在紧致定义域上一致连续，但定义域无界时未必如此： $f(x) = x^2$ 在 $\mathbb{R}$ 上连续，取 $x' = x + 1/x$ 可见输入距离趋于零而输出距离 $|f(x') - f(x)| = 2 + 1/x^2$ 不趋于零。

若存在常数 $L \geq 0$, 使所有 $x, x' \in X$ 都满足

$$d_Y(f(x), f(x')) \leq L d_X(x, x'), \quad (2.3)$$

则称 f 为 **L -Lipschitz 连续** (Lipschitz continuous)。它不仅用同一个 δ 控制整个定义域, 还给出输出变化相对于输入变化的线性上界, 因而蕴含一致连续。函数 $f(x) = \sqrt{x}$ 在 $[0, 1]$ 上一致连续, 却不是 Lipschitz 连续: 若存在有限 L , 令 $x' = 0$ 便会要求 $\sqrt{x} \leq Lx$, 即 $1/\sqrt{x} \leq L$, 这在 $x \downarrow 0$ 时不可能成立。

2.2.3 紧致性把局部控制变成整体控制

设 $K \subseteq X$ 。若一族开集的并包含 K , 就称这族开集为 K 的 **开覆盖** (open cover); 若从中选出的有限个开集仍覆盖 K , 它们就构成 **有限子覆盖** (finite subcover)。集合 K 的每个开覆盖都能选出有限子覆盖时, 称 K 为 **紧致** (compact)。在度量空间中, 这一定义等价于 **序列紧致性**: 集合中的每个序列都有一个子序列收敛到仍在该集合中的点。后一种表述更适合分析算法产生的点列, 因为它直接提供候选极限。

在有限维欧氏空间 $\mathbb{R}^d$ 中, Heine-Borel 定理说明紧致等价于闭且有界。这个结论不能原样搬到一般度量空间。考虑所有有界实数序列组成的空间

$$\ell^\infty = \left\{ \mathbf{x} = (x_1, x_2, \dots) : \sup_{k \geq 1} |x_k| < \infty \right\}, \quad d(\mathbf{x}, \mathbf{y}) = \sup_{k \geq 1} |x_k - y_k|.$$

令 $\mathbf{e}_n$ 只有第 n 个坐标为 1, 其余坐标为 0。集合 $\{\mathbf{e}_n : n \geq 1\}$ 有界, 而且在 ℓ^∞ 中是闭集; 但 $n \neq m$ 时 $d(\mathbf{e}_n, \mathbf{e}_m) = 1$, 所以任何子序列都不是柯西数列, 更不可能收敛。一般空间中“闭且有界”不足以替代紧致, 正是因为无穷多个彼此分离的方向可能留在同一个有界球内。

定理 2.2 紧致集上的极值定理 设 K 是非空紧致度量空间, $f : K \rightarrow \mathbb{R}$ 连续, 则 f 在 K 上同时达到最小值与最大值。

证明. 只证明最小值情形。令 $m = \inf_{x \in K} f(x)$ 。先说明 m 有限: 若 f 无下界, 可为每个 n 选取 $x_n \in K$ 使 $f(x_n) < -n$ 。紧致性给出收敛子序列 $x_{n_k} \rightarrow x^* \in K$, 连续性却要求 $f(x_{n_k}) \rightarrow f(x^*) \in \mathbb{R}$, 与 $f(x_{n_k}) < -n_k \rightarrow -\infty$ 矛盾。

按下确界定义, 对每个 n 可选 $x_n \in K$ 使 $f(x_n) < m + 1/n$ 。再次由紧致性, 存在子序列 $x_{n_k} \rightarrow x^* \in K$ 。连续性给出

$$f(x^*) = \lim_{k \rightarrow \infty} f(x_{n_k}) = m,$$

故 x^* 达到最小值。对 $-f$ 应用同一结论便得到最大值。 ■

这个证明展示了紧致性的两项作用：从近似最优点列中抽出收敛子序列，并保证极限仍在可行集合内。连续性随后把函数值极限传到该点。任一条件缺失都可能使最优解不存在。

示例 2.3 极值存在条件怎样失效 在开区间 $(0, 1)$ 上，连续函数 $f(x) = x$ 的下确界为 0，却没有最小点；定义域不紧致，极限点 0 被排除。把定义域改成闭但不紧致的 $\mathbb{R}$ ，连续函数 $f(x) = e^x$ 仍有下确界 0 而不达到它。另一方面，在紧致集合 $[0, 1]$ 上定义

$$g(0) = 1, \quad g(x) = x \quad (x > 0),$$

则 $\inf g = 0$ 也未达到；这次失败的是 g 在 0 处不连续。三个例子分别表明“连续”、“闭”或“有界”中的单独一项都不是一般的极值存在保证。

2.3 导数与线性近似

2.3.1 导数是局部变化率

一元函数 $f: \mathbb{R} \rightarrow \mathbb{R}$ 在 x 处的**导数** (derivative) 定义为

$$f'(x) = \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h},$$

前提是这个双侧极限存在。它说明输入发生小变化 h 时，函数增量的一阶部分是 $f'(x)h$ ：

$$f(x+h) = f(x) + f'(x)h + o(|h|). \quad (2.4)$$

式中的小 o 比“ h 很小”更精确：余项 $r(h)$ 满足 $r(h)/|h| \rightarrow 0$ 。导数存在必然推出函数在该点连续，但连续不保证可导，例如 $|x|$ 在 0 处连续，左右导数却分别为 -1 和 1 。跳变还会破坏连续性，因而更不可能可导：阈值函数 $\mathbb{I}\{x \geq 0\}$ 在 0 处的左右函数值极限不同。尖点与跳变都会使经典导数失效，但前者仍连续，后者连零阶近似也无法通过同一个函数值连接两侧。

对 $f: \mathbb{R}^d \rightarrow \mathbb{R}$ ，沿方向 $\mathbf{v} \in \mathbb{R}^d$ 的**方向导数** (directional derivative) 是

$$D_{\mathbf{v}}f(\mathbf{x}) = \lim_{t \rightarrow 0} \frac{f(\mathbf{x} + t\mathbf{v}) - f(\mathbf{x})}{t}.$$

取 $\mathbf{v}$ 为第 j 个坐标方向 $\mathbf{e}_j$ ，就得到**偏导数** (partial derivative) $\partial f / \partial x_j$ 。方向导数只检查一条直线，而整体可微性要求所有小扰动共享同一个线性近似。

2.3.2 全微分统一所有方向

函数 $f: \mathbb{R}^d \rightarrow \mathbb{R}$ 在 $\mathbf{x}$ 处**可微** (differentiable), 是指存在一个线性映射 $A: \mathbb{R}^d \rightarrow \mathbb{R}$, 使

$$f(\mathbf{x} + \mathbf{h}) = f(\mathbf{x}) + A(\mathbf{h}) + o(\|\mathbf{h}\|_2). \quad (2.5)$$

在欧氏空间中, 每个这样的线性泛函都可写为 $A(\mathbf{h}) = \langle \nabla f(\mathbf{x}), \mathbf{h} \rangle$, 其中

$$\nabla f(\mathbf{x}) = \left(\frac{\partial f}{\partial x_1}(\mathbf{x}), \dots, \frac{\partial f}{\partial x_d}(\mathbf{x}) \right)^\top$$

称为**梯度** (gradient)。因此梯度不是若干偏导数的随意排列, 而是表示局部线性映射的向量; 扰动 $\mathbf{h}$ 通过内积变成函数的一阶变化。

可微必然推出所有方向导数存在, 并且 $D_{\mathbf{v}}f(\mathbf{x}) = \langle \nabla f(\mathbf{x}), \mathbf{v} \rangle$ 。反向结论不成立, 仅有偏导数更不够。

示例 2.4 偏导数存在但不可微 定义 $f: \mathbb{R}^2 \rightarrow \mathbb{R}$ 为

$$f(x, y) = \begin{cases} \frac{xy}{\sqrt{x^2 + y^2}}, & (x, y) \neq (0, 0), \\ 0, & (x, y) = (0, 0). \end{cases}$$

沿两条坐标轴, 函数恒为 0, 所以 $\partial f / \partial x(0, 0) = \partial f / \partial y(0, 0) = 0$ 。若 f 在原点可微, 候选线性部分只能是零映射。可是沿 $\mathbf{h} = (t, t)$,

$$\frac{|f(t, t) - f(0, 0)|}{\|(t, t)\|_2} = \frac{|t|/\sqrt{2}}{\sqrt{2}|t|} = \frac{1}{2},$$

余项与 $\|\mathbf{h}\|_2$ 之比不趋于零, 故 f 在原点不可微。偏导数只看坐标轴, 遗漏了其他接近路径。

一个常用的充分条件是: 若 f 的所有一阶偏导数在 $\mathbf{x}$ 的某个邻域内存在, 并在 $\mathbf{x}$ 处连续, 则 f 在 $\mathbf{x}$ 处可微。注意这只是方便核对的充分条件, 不是必要条件; 可微函数的偏导数不一定在该点附近连续。

2.3.3 中值定理把局部导数连接到有限变化

若 $f: [a, b] \rightarrow \mathbb{R}$ 在 $[a, b]$ 上连续、在 (a, b) 上可导, 则**中值定理** (mean value theorem) 保证存在 $c \in (a, b)$ 使

$$f(b) - f(a) = f'(c)(b - a). \quad (2.6)$$

所以, 若区间上 $|f'(x)| \leq L$, 便有 $|f(b) - f(a)| \leq L|b - a|$ 。这说明有界导数可以推出 Lipschitz 控制。多元标量函数也可沿线段使用一元中值定理: 当连接 $\mathbf{x}$ 与 $\mathbf{y}$ 的线段位于定义域且 f 在线段邻域可微时,

$$|f(\mathbf{y}) - f(\mathbf{x})| \leq \sup_{0 \leq t \leq 1} \|\nabla f(\mathbf{x} + t(\mathbf{y} - \mathbf{x}))\|_2 \|\mathbf{y} - \mathbf{x}\|_2.$$

这里控制的是标量函数值差。对向量值函数, 不能一般地断言存在一个共同的 c 让整个向量增量等于单个 Jacobian 矩阵乘以输入增量; 应使用积分形式或范数上界。

2.4 向量值函数与链式法则

2.4.1 Jacobian 矩阵表示局部线性映射

设 $f: \mathbb{R}^d \rightarrow \mathbb{R}^m$ 。若存在矩阵 $\mathbf{J}_f(\mathbf{x}) \in \mathbb{R}^{m \times d}$ 使

$$f(\mathbf{x} + \mathbf{h}) = f(\mathbf{x}) + \mathbf{J}_f(\mathbf{x})\mathbf{h} + o(\|\mathbf{h}\|_2), \quad (2.7)$$

则称 f 在 $\mathbf{x}$ 处可微, $\mathbf{J}_f(\mathbf{x})$ 称为 **Jacobian 矩阵** (Jacobian matrix)。其第 i, j 个元素是 $\partial f_i / \partial x_j$ 。矩阵有 m 行、 d 列, 因为它把 d 维输入扰动映射成 m 维输出扰动。

若 $g: \mathbb{R}^m \rightarrow \mathbb{R}^p$ 在 $f(\mathbf{x})$ 处可微, 则复合映射满足

$$\mathbf{J}_{g \circ f}(\mathbf{x}) = \mathbf{J}_g(f(\mathbf{x}))\mathbf{J}_f(\mathbf{x}). \quad (2.8)$$

这就是**链式法则**(chain rule)。维度同时给出乘法次序: $(p \times m)(m \times d) = p \times d$, 反向相乘往往没有定义。即使两个方阵能够交换书写顺序, 矩阵乘法通常也不交换, 不能据标量求导经验调换因子。

当最终输出 $\ell: \mathbb{R}^m \rightarrow \mathbb{R}$ 为标量时, 采用列向量梯度可把链式法则写成

$$\nabla_{\mathbf{x}}(\ell \circ f)(\mathbf{x}) = \mathbf{J}_f(\mathbf{x})^\top \nabla_{\mathbf{y}} \ell(\mathbf{y}) \Big|_{\mathbf{y}=f(\mathbf{x})}.$$

局部线性映射在前向计算中按 $\mathbf{J}_f$ 作用, 在标量目标的反向计算中按转置 $\mathbf{J}_f^\top$ 传回。这是后续反向传播的线性代数核心, 但具体网络结构留到模型章节。

例如, 若 $f: \mathbb{R}^2 \rightarrow \mathbb{R}^3$ 且 $g: \mathbb{R}^3 \rightarrow \mathbb{R}$, 则 $\mathbf{J}_f \in \mathbb{R}^{3 \times 2}$ 、 $\mathbf{J}_g \in \mathbb{R}^{1 \times 3}$, 复合映射的 Jacobian 形状为 $(1 \times 3)(3 \times 2) = 1 \times 2$ 。对应的列向量梯度从标量输出传回时, 先乘 $\mathbf{J}_g^\top$ 得到三维向量, 再乘 $\mathbf{J}_f^\top$ 得到二维向量。这两个方向描述的是同一个线性复合, 只是向量表示的方向相反。

另一个常用例子是 n 维**归一化指数映射** (softmax)。对 $\mathbf{z} \in \mathbb{R}^n$, 令

$$s_i(\mathbf{z}) = \frac{e^{z_i}}{\sum_{k=1}^n e^{z_k}}, \quad i = 1, \dots, n.$$

记分母为 $Z = \sum_k e^{z_k}$ 。指数函数求导和商法则给出

$$\frac{\partial s_i}{\partial z_j} = \frac{\mathbb{I}\{i=j\}e^{z_i}Z - e^{z_i}e^{z_j}}{Z^2} = s_i(\mathbb{I}\{i=j\} - s_j).$$

因此整个 Jacobian 矩阵为

$$\mathbf{J}_s(\mathbf{z}) = \text{diag}(\mathbf{s}) - \mathbf{s}\mathbf{s}^\top. \quad (2.9)$$

对角项 $s_i(1 - s_i)$ 描述提高 z_i 对自身分量的影响, 非对角项 $-s_i s_j$ 来自共同分母: 提高一个坐标会压低其余归一化分量。每行元素之和为零, 这也与给所有 z_i 同时加同一常数不改变输出相符。

2.4.2 全微分处理矩阵变量

矩阵 $\mathbf{X} \in \mathbb{R}^{m \times n}$ 可以看成 mn 个坐标组成的对象。对标量函数 $f(\mathbf{X})$, 本书使用 Frobenius 迹内积

$$\langle \mathbf{A}, \mathbf{B} \rangle_F = \text{tr}(\mathbf{A}^\top \mathbf{B})$$

定义矩阵梯度: 若一阶全微分能够写成

$$df = \langle \nabla_{\mathbf{X}} f, d\mathbf{X} \rangle_F = \text{tr}((\nabla_{\mathbf{X}} f)^\top d\mathbf{X}), \quad (2.10)$$

则 $\nabla_{\mathbf{X}} f$ 与 $\mathbf{X}$ 形状相同。计算时可用乘积法则展开微分, 再利用

$$\text{tr}(\mathbf{AB}) = \text{tr}(\mathbf{BA}), \quad \text{tr}(\mathbf{ABC}) = \text{tr}(\mathbf{BCA}),$$

把 $d\mathbf{X}$ 移动到末端。迹只允许循环移位, 不能任意交换相邻矩阵。

2.4.3 四个常用矩阵微分

先考虑二次型 $q(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x}$, 其中 $\mathbf{A} \in \mathbb{R}^{d \times d}$ 固定。由乘积法则,

$$\begin{aligned} dq &= (d\mathbf{x})^\top \mathbf{A} \mathbf{x} + \mathbf{x}^\top \mathbf{A} d\mathbf{x} \\ &= \mathbf{x}^\top (\mathbf{A}^\top + \mathbf{A}) d\mathbf{x}. \end{aligned}$$

因此

$$\nabla_{\mathbf{x}}(\mathbf{x}^\top \mathbf{A} \mathbf{x}) = (\mathbf{A} + \mathbf{A}^\top) \mathbf{x}. \quad (2.11)$$

只有当 $\mathbf{A}$ 对称时才能化为 $2\mathbf{A}\mathbf{x}$ 。直接写成 $2\mathbf{A}\mathbf{x}$ 会悄然加入对称性条件。

对固定的 $\mathbf{A} \in \mathbb{R}^{m \times n}$, 令 $f(\mathbf{X}) = \text{tr}(\mathbf{A}^\top \mathbf{X})$ 。它的微分已经符合式 (2.10),

所以

$$\nabla_{\mathbf{X}} \operatorname{tr}(\mathbf{A}^{\top} \mathbf{X}) = \mathbf{A}. \quad (2.12)$$

这个简单关系常用于从迹表达式中读出梯度。

若方阵 $\mathbf{X}$ 可逆, 由恒等式 $\mathbf{X}\mathbf{X}^{-1} = \mathbf{I}$ 取微分可得

$$(\mathrm{d}\mathbf{X})\mathbf{X}^{-1} + \mathbf{X} \mathrm{d}(\mathbf{X}^{-1}) = \mathbf{0}.$$

左乘 $\mathbf{X}^{-1}$ 后得到

$$\mathrm{d}(\mathbf{X}^{-1}) = -\mathbf{X}^{-1}(\mathrm{d}\mathbf{X})\mathbf{X}^{-1}. \quad (2.13)$$

两个 $\mathbf{X}^{-1}$ 位于扰动两侧, 不能合并成 $-\mathbf{X}^{-2}\mathrm{d}\mathbf{X}$, 因为 $\mathrm{d}\mathbf{X}$ 未必与 $\mathbf{X}^{-1}$ 交换。

最后设 $\mathbf{X} \in \mathbb{R}^{d \times d}$ 正定, 因而 $\det \mathbf{X} > 0$ 且 $\log \det \mathbf{X}$ 有定义。Jacobi 行列式公式给出

$$\mathrm{d} \det \mathbf{X} = \det(\mathbf{X}) \operatorname{tr}(\mathbf{X}^{-1} \mathrm{d}\mathbf{X}).$$

再应用标量对数的链式法则,

$$\mathrm{d} \log \det \mathbf{X} = \operatorname{tr}(\mathbf{X}^{-1} \mathrm{d}\mathbf{X}), \quad \nabla_{\mathbf{X}} \log \det \mathbf{X} = \mathbf{X}^{-\top}. \quad (2.14)$$

正定矩阵对称, 所以 $\mathbf{X}^{-\top} = \mathbf{X}^{-1}$; 对一般可逆实矩阵, $\log \det \mathbf{X}$ 还需要 $\det \mathbf{X} > 0$, 而梯度应保留转置。以上推导依赖的不是元素级记忆口诀, 而是局部线性近似、乘积次序和迹内积三件事。

2.5 二阶导数与曲率

2.5.1 Hessian 矩阵描述梯度怎样变化

一阶近似只保留函数的局部斜率。若还要判断这个斜率怎样随位置改变, 就需要 **Hessian 矩阵** (Hessian matrix)。设 $f: \mathbb{R}^d \rightarrow \mathbb{R}$ 在 $\mathbf{x}$ 附近二阶可微, 定义

$$\nabla^2 f(\mathbf{x}) = \begin{bmatrix} \frac{\partial^2 f}{\partial x_1^2} & \cdots & \frac{\partial^2 f}{\partial x_1 \partial x_d} \\ \vdots & \ddots & \vdots \\ \frac{\partial^2 f}{\partial x_d \partial x_1} & \cdots & \frac{\partial^2 f}{\partial x_d^2} \end{bmatrix}.$$

若二阶偏导数在邻域内连续, 混合偏导数可以交换, Hessian 矩阵因而对称。对方向 $\mathbf{v}$, 二次型 $\mathbf{v}^{\top} \nabla^2 f(\mathbf{x}) \mathbf{v}$ 是沿直线 $t \mapsto f(\mathbf{x} + t\mathbf{v})$ 在 $t = 0$ 处的二阶导数。它衡量的不是函数值大小, 而是沿该方向的一阶斜率变化。

对二次函数

$$f(\mathbf{x}) = \frac{1}{2} \mathbf{x}^{\top} \mathbf{A} \mathbf{x} + \mathbf{b}^{\top} \mathbf{x} + c,$$

只有 $\mathbf{A}$ 的对称部分影响函数值。令 $\mathbf{H} = (\mathbf{A} + \mathbf{A}^{\top})/2$, 则 $\nabla f(\mathbf{x}) = \mathbf{H} \mathbf{x} + \mathbf{b}$

且 $\nabla^2 f(\mathbf{x}) = \mathbf{H}$ 。正特征值对应向上弯曲的方向，负特征值对应向下弯曲的方向；特征值绝对值相差很大时，不同方向的尺度也相差很大。

2.5.2 Taylor 展开把局部曲率写入余项

设连接 $\mathbf{x}$ 与 $\mathbf{x} + \mathbf{h}$ 的线段包含在一个开集内，并且 f 在该开集上二阶连续可微。对一元函数 $\phi(t) = f(\mathbf{x} + t\mathbf{h})$ 使用 Taylor 定理，存在 $\theta \in (0, 1)$ 使

$$f(\mathbf{x} + \mathbf{h}) = f(\mathbf{x}) + \nabla f(\mathbf{x})^\top \mathbf{h} + \frac{1}{2} \mathbf{h}^\top \nabla^2 f(\mathbf{x} + \theta \mathbf{h}) \mathbf{h}. \quad (2.15)$$

若只假设 Hessian 矩阵沿线段连续，也可以使用不挑选中间点的积分余项

$$f(\mathbf{x} + \mathbf{h}) = f(\mathbf{x}) + \nabla f(\mathbf{x})^\top \mathbf{h} + \int_0^1 (1-t) \mathbf{h}^\top \nabla^2 f(\mathbf{x} + t\mathbf{h}) \mathbf{h} dt.$$

于是当 $\mathbf{h} \rightarrow \mathbf{0}$ 时，

$$f(\mathbf{x} + \mathbf{h}) = f(\mathbf{x}) + \nabla f(\mathbf{x})^\top \mathbf{h} + \frac{1}{2} \mathbf{h}^\top \nabla^2 f(\mathbf{x}) \mathbf{h} + o(\|\mathbf{h}\|_2^2). \quad (2.16)$$

式 (2.16) 是局部结论。若要在一个区域内给出统一余项界，还需控制该区域上的 Hessian 矩阵连续性或 Lipschitz 常数，不能仅凭一点处的二阶导数。

2.5.3 二阶判据区分极值与鞍点

设 $\mathbf{x}^*$ 是开集内部的局部极小点，且 f 在该点可微。对每个方向 $\mathbf{v}$ 考察 $f(\mathbf{x}^* + t\mathbf{v})$ ，一元函数的必要条件给出 $\nabla f(\mathbf{x}^*)^\top \mathbf{v} = 0$ 。这对所有 $\mathbf{v}$ 成立，因此

$$\nabla f(\mathbf{x}^*) = \mathbf{0}. \quad (2.17)$$

若 f 还在该点二阶可微，同样沿任意方向使用一元二阶必要条件，可得

$$\mathbf{v}^\top \nabla^2 f(\mathbf{x}^*) \mathbf{v} \geq 0 \quad \text{对所有 } \mathbf{v}, \quad (2.18)$$

即 Hessian 矩阵半正定。局部极大点对应半负定。这些只是必要条件： $f(x) = x^4$ 与 $f(x) = -x^4$ 在 0 处分别有严格局部极小值和严格局部极大值，二者的二阶导数却都为零； $f(x) = x^3$ 在 0 处的一阶导数和二阶导数也都为零，却没有极值。Hessian 矩阵半正定或半负定本身不能决定驻点类型。

正定 Hessian 矩阵给出更强的充分条件。若 f 在 $\mathbf{x}^*$ 的某个邻域内二阶连续可微， $\nabla f(\mathbf{x}^*) = \mathbf{0}$ 且 $\nabla^2 f(\mathbf{x}^*)$ 正定，则其最小特征值为某个 $\lambda > 0$ 。由 Hessian 矩阵的连续性，充分靠近 $\mathbf{x}^*$ 时，任意方向上的二次型仍至少为 $(\lambda/2)\|\mathbf{h}\|_2^2$ 。代入 Taylor 积分余项可得

$$f(\mathbf{x}^* + \mathbf{h}) - f(\mathbf{x}^*) \geq \frac{\lambda}{4} \|\mathbf{h}\|_2^2 > 0$$

对充分小的非零 h 成立, 故 x^* 是严格局部极小点。负定情形给出严格局部极大点。

若驻点处 Hessian 矩阵既有正特征值又有负特征值, 沿相应特征向量的小扰动会使函数值分别增加和减小, 该点称为**鞍点** (saddle point)。例如 $f(x, y) = x^2 - y^2$ 的原点就是鞍点。若 Hessian 矩阵仅半正定或含零特征值, 二阶判据可能没有结论, 必须查看更高阶项或函数的其他结构。上述必要条件还假定位于无约束开集内部; 边界极小点的梯度可以不为零, 受约束问题需要后续章节的可行方向与乘子条件。

2.6 积分与平均

2.6.1 测度先规定哪些集合能够赋予大小

有限加权和把每个位置的函数值乘以一个权重再相加。积分把“位置”推广成可能不可数的集合, 因此要先说明哪些集合可被测量, 以及它们各有多大。集合 X 上的 σ **代数** (sigma-algebra) $\mathcal{A}$ 是一族子集, 满足

$$X \in \mathcal{A}, \quad A \in \mathcal{A} \implies X \setminus A \in \mathcal{A}, \quad A_1, A_2, \dots \in \mathcal{A} \implies \bigcup_{n=1}^{\infty} A_n \in \mathcal{A}.$$

这些条件还蕴含对可数交封闭。 $\mathcal{A}$ 中的集合称为可测集合。只要求可数次运算而非任意次运算, 是因为极限与可数序列相连, 同时又能避免给所有过于复杂的子集强行赋予相容的长度。

测度 (measure) 是映射 $\mu : \mathcal{A} \rightarrow [0, \infty]$, 满足 $\mu(\emptyset) = 0$, 并且对两两不交的 $A_1, A_2, \dots$ 有

$$\mu\left(\bigcup_{n=1}^{\infty} A_n\right) = \sum_{n=1}^{\infty} \mu(A_n).$$

三元组 $(X, \mathcal{A}, \mu)$ 称为**测度空间** (measure space)。实数上的 Lebesgue 测度把区间 (a, b) 赋值为 $b - a$; 有限集合上的计数测度把集合赋值为元素个数; 给有限点 x_i 分配质量 $w_i \geq 0$ 则得到 $\mu(A) = \sum_{i: x_i \in A} w_i$ 。因此有限加权和、通常的面积积分和后续的概率期望可以使用同一套记号¹。

在拓扑空间中, 由所有开集生成的最小 σ 代数称为**Borel σ 代数** (Borel sigma-algebra)。实数上的开区间因而都是 Borel 可测集。Lebesgue 测度可先由区间覆盖定义外部大小, 再用可测性判据扩张长度; 把所有 Lebesgue 零测集的子集一并加入 Borel σ 代数, 得到相对于该测度的完备化。这里“完备”表示零测集的任意子集仍可测, 不同于第 2.12 节中“柯西数列不会逃出空间”的完备性。

可数可加性还给出集合极限与测度之间的连续性。若 $A_1 \subseteq A_2 \subseteq \dots$ 且 $A = \bigcup_n A_n$, 令 $B_1 = A_1$, $B_n = A_n \setminus A_{n-1}$, 则 B_n 两两不交且 $A_n = \bigcup_{k=1}^n B_k$ 。

¹ G. B. Folland, *Real Analysis: Modern Techniques and Their Applications*, Wiley, 1999, 2nd ed.

因此

$$\mu(A) = \sum_{k=1}^{\infty} \mu(B_k) = \lim_{n \rightarrow \infty} \mu(A_n).$$

若 $A_1 \supseteq A_2 \supseteq \cdots$ 且 $\mu(A_1) < \infty$, 对递增集合 $A_1 \setminus A_n$ 应用上一结论可得 $\mu(\bigcap_n A_n) = \lim_n \mu(A_n)$ 。递减情形需要 $\mu(A_1) < \infty$: 若每个 A_n 的测度都为无穷, 就不能通过“无穷减无穷”得到结论。例如 Lebesgue 测度下 $A_n = (n, \infty)$ 递减到空集, 但每个 A_n 的测度仍为无穷。

若 $\mu(N) = 0$, 则 N 称为**零测集** (null set)。某性质除一个零测集外处处成立, 就称它**几乎处处** (almost everywhere) 成立, 常缩写为 a.e.。这不是说例外集合为空, 而是说当前测度不给它任何质量; 换用另一个测度后, 原来的例外可能不再可忽略。

2.6.2 可测函数保证阈值事件可以测量

函数 $f: X \rightarrow \overline{\mathbb{R}} = [-\infty, \infty]$ 称为**可测函数** (measurable function), 若每个 $a \in \mathbb{R}$ 对应的集合

$$\{x \in X : f(x) > a\}$$

都属于 $\mathcal{A}$ 。这保证按函数值设置阈值产生的集合可以赋予测度。可测函数列的逐点极限, 以及可数族可测函数的逐点上确界和下确界, 仍是可测函数。连续实函数相对于 Borel σ 代数可测, 但可测性比连续性弱得多。

形如

$$s(x) = \sum_{j=1}^m a_j \mathbb{I}_{A_j}(x), \quad a_j \geq 0, \quad A_j \in \mathcal{A},$$

且 A_j 两两不交的函数称为非负**简单函数** (simple function)。它只取有限多个值, 其积分自然定义为

$$\int_X s \, d\mu = \sum_{j=1}^m a_j \mu(A_j). \quad (2.19)$$

即使某个 $\mu(A_j) = \infty$, 该定义仍允许积分取 $+\infty$, 并约定 $0 \cdot \infty = 0$ 。同一个简单函数可能有不同的分组表示; 把这些表示按所有取值集合的交集细分成共同的两两不交集后, 有限可加性给出相同的和, 因此式 (2.19) 不依赖具体表示。

每个非负可测函数 f 都能由一系列非负简单函数从下方逐点逼近。对 $n \geq 1$, 一个明确的构造是

$$s_n(x) = \sum_{k=0}^{n2^n-1} \frac{k}{2^n} \mathbb{I}_{\{k2^{-n} \leq f(x) < (k+1)2^{-n}\}} + n \mathbb{I}_{\{f(x) \geq n\}}. \quad (2.20)$$

它先把函数值截断在 n , 再向下舍入到间距为 2^{-n} 的格点。截断高度随

n 增加, 格点也逐次细化, 所以 $0 \leq s_n \leq s_{n+1} \leq f$ 。若 $f(x) < \infty$, 当 $n > f(x)$ 时还有 $0 \leq f(x) - s_n(x) < 2^{-n}$; 若 $f(x) = +\infty$, 则 $s_n(x) = n$ 。因此 $s_n(x) \uparrow f(x)$ 对每个 x 成立。非负可测函数的积分定义为

$$\int_X f \, d\mu = \sup \left\{ \int_X s \, d\mu : 0 \leq s \leq f, s \text{ 为简单函数} \right\}. \quad (2.21)$$

这里允许结果为 $+\infty$ 。这个定义不要求把定义域切成连续小区间, 而是按函数值分层, 所以能自然处理极限和零测例外。

引理 2.5 非负积分的线性与单调性 设 $f, g : X \rightarrow [0, \infty]$ 可测, $\alpha, \beta \geq 0$ 。若 $f \leq g$ 几乎处处, 则

$$\int_X f \, d\mu \leq \int_X g \, d\mu.$$

此外, 在 $0 \cdot \infty = 0$ 的约定下,

$$\int_X (\alpha f + \beta g) \, d\mu = \alpha \int_X f \, d\mu + \beta \int_X g \, d\mu.$$

证明. 对非负简单函数, 把两种表示细分到同一组两两不交的可测集上, 式 (2.19) 就退化为有限个非负数的求和, 因而具有单调性和非负线性。简单函数在可测零测集上的部分积分为零, 所以由积分定义可知, 两个可测非负函数若只在一个可测零测集上取值不同, 其积分相同。这里修改后的函数仍须可测; 在未完备测度空间中, 不能对零测集作任意修改而省略这项要求。

对 $f \leq g$ 几乎处处的情形, 集合 $N = \{x : f(x) > g(x)\}$ 可测且 $\mu(N) = 0$ 。把 f 在 N 上改为 0 得到可测函数 $\tilde{f}$, 其积分与 f 相同, 并且逐点满足 $\tilde{f} \leq g$ 。此时每个满足 $0 \leq s \leq \tilde{f}$ 的简单函数也满足 $s \leq g$; 在式 (2.21) 中取上确界便得到单调性。

还需把简单函数的线性提升到一般非负函数。先注意, 若非负简单函数 $u_n \uparrow u$, 则 $\int u_n \, d\mu \uparrow \int u \, d\mu$ 。单调性已经给出 “ $\leq$ ” 方向。反过来, 任取 $s = \sum_{j=1}^m a_j \mathbb{1}_{A_j} \leq u$, 其中 $a_j > 0$ 且 A_j 两两不交, 并固定 $c \in (0, 1)$ 。集合

$$A_{j,n} = A_j \cap \{x : u_n(x) \geq ca_j\}$$

随 n 递增到 A_j , 所以测度的下连续性给出

$$\lim_{n \rightarrow \infty} \int_X u_n \, d\mu \geq c \sum_{j=1}^m a_j \mu(A_j) = c \int_X s \, d\mu.$$

令 $c \uparrow 1$, 再对所有 $s \leq u$ 取上确界, 就得到所需等式。现在分别取非负简

单函数 $s_n \uparrow f$ 和 $t_n \uparrow g$, 则 $\alpha s_n + \beta t_n \uparrow \alpha f + \beta g$ 。应用刚证明的简单函数单调极限性质和简单函数的线性性, 即得

$$\int_X (\alpha f + \beta g) d\mu = \lim_{n \rightarrow \infty} \left(\alpha \int_X s_n d\mu + \beta \int_X t_n d\mu \right),$$

右侧正是结论中的两个积分之和。 ■

2.6.3 有符号积分需要控制正负两部分

对可测实函数 f , 定义

$$f^+(x) = \max\{f(x), 0\}, \quad f^-(x) = \max\{-f(x), 0\}.$$

于是 $f = f^+ - f^-$ 且 $|f| = f^+ + f^-$ 。只要 $\int f^+ d\mu$ 与 $\int f^- d\mu$ 不同时为无穷, 就可以用两者之差定义 $\int f d\mu$ 。若

$$\int_X |f| d\mu < \infty, \quad (2.22)$$

就称 f **绝对可积** (absolutely integrable) 或 Lebesgue 可积。此时正负部分都有限, 积分没有“无穷减无穷”的歧义, 并满足

$$\left| \int_X f d\mu \right| \leq \int_X |f| d\mu.$$

在闭区间上有界且 Riemann 可积的函数也 Lebesgue 可积, 两种积分取值相同。Lebesgue 积分并非否定熟悉的面积解释, 而是扩大可处理的函数, 并让两个可测且几乎处处相等的函数具有相同积分。例如在 Lebesgue 测度下, 修改可测函数在单点上的值仍得到可测函数, 也不改变积分。反过来, 积分有限不表示函数处处有界, 也不自动给出连续性。

2.6.4 乘积测度描述两个坐标上的平均

给定两个测度空间 $(X, \mathcal{A}, \mu)$ 与 $(Y, \mathcal{B}, \nu)$, 乘积 σ 代数 $\mathcal{A} \otimes \mathcal{B}$ 由矩形集合 $A \times B$ 生成。在常用的 σ 有限条件下, 存在唯一的**乘积测度** (product measure) $\mu \otimes \nu$ 满足

$$(\mu \otimes \nu)(A \times B) = \mu(A)\nu(B).$$

对矩形上的指示函数, 先对 x 积分或先对 y 积分都得到同一个乘积。一般函数能否继续交换积分次序, 则取决于非负性或绝对可积性, 第 2.8 节会给出准确条件。这里的 σ 有限是指空间能写成可数个有限测度集合之并; 若脱离这一常见框架, 乘积测度的唯一性和相应积分结论需要更谨慎的版本。

有限网格把这个构造还原为双重求和。若 $X = \{x_1, \dots, x_m\}$ 、 $Y = \{y_1, \dots, y_n\}$ 分别带权重 u_i, v_j , 则

$$\int_{X \times Y} f d(\mu \otimes \nu) = \sum_{i=1}^m \sum_{j=1}^n f(x_i, y_j) u_i v_j.$$

有限和可以直接交换次序；一般测度空间中的累次积分还要处理无穷值与极限，不能只由矩形公式推出。

2.7 坐标变换及其积分应用

2.7.1 Jacobian 矩阵的行列式衡量局部体积变化

一维换元中， $u = T(x)$ 把长度 dx 缩放为约 $|T'(x)|dx$ 。在 d 维，局部线性近似

$$T(\mathbf{x} + \mathbf{h}) \approx T(\mathbf{x}) + \mathbf{J}_T(\mathbf{x})\mathbf{h}$$

把一个小平行多面体的有向体积乘以 $\det \mathbf{J}_T(\mathbf{x})$ ，普通体积则乘以其绝对值。行列式为零意味着至少一个方向被压扁，局部逆映射通常不再存在。

设 $U, V \subseteq \mathbb{R}^d$ 为开集， $T: U \rightarrow V$ 是连续可微双射，逆映射也连续可微，并且 $\det \mathbf{J}_T(\mathbf{x}) \neq 0$ 。对非负可测函数或绝对可积函数 g ，多维换元公式为

$$\int_V g(\mathbf{y}) d\mathbf{y} = \int_U g(T(\mathbf{x})) |\det \mathbf{J}_T(\mathbf{x})| d\mathbf{x}. \quad (2.23)$$

绝对值不可省略，因为积分中的体积不随坐标方向翻转而变成负数。一维单调换元是 $d = 1$ 的特例；若在定积分中保留有向上下限，也可让导数符号由上下限次序吸收。公式的证明可理解为把 U 分成足够小的区域：在每一块上用 $T(\mathbf{x} + \mathbf{h}) \approx T(\mathbf{x}) + \mathbf{J}_T(\mathbf{x})\mathbf{h}$ 替代原映射，线性映射把该块体积乘以 $|\det \mathbf{J}_T(\mathbf{x})|$ ，再让分割尺度趋于零。这条路线只提供直观框架；严格证明还要控制局部近似误差、像集重叠和可测逼近，不能把逐点线性化直接当作全局换元等式。

示例 2.6 极坐标中的面积权重 令 $D = \{\mathbf{x} \in \mathbb{R}^2 : \|\mathbf{x}\|_2 \leq 1\}$ ，并令 $T(r, \theta) = (r \cos \theta, r \sin \theta)$ 。在开集 $(0, 1) \times (0, 2\pi)$ 上， T 是到开圆盘内部去掉原点和正 x 轴径向接缝后的区域的连续可微双射，逆映射也连续可微。其 Jacobian 矩阵的行列式为

$$\det \begin{bmatrix} \cos \theta & -r \sin \theta \\ \sin \theta & r \cos \theta \end{bmatrix} = r.$$

圆周、原点和径向接缝都是二维零测集；参数矩形的边界也是零测

集。因此在上述开集上应用换元公式，再补回这些零测部分，便得到

$$\int_D 1 \, d\mathbf{x} = \int_0^{2\pi} \int_0^1 r \, dr \, d\theta = \pi.$$

这里积分上下限包含端点不改变积分值。若参数化在正测度区域上重复覆盖，则不能直接使用上述双射版本，否则同一点会被重复计数。

2.7.2 分部积分把导数从一个因子移到另一个因子

若 $u, v \in C^1([a, b])$ ，由乘积求导 $(uv)' = u'v + uv'$ 并在 $[a, b]$ 上积分，可得

$$\int_a^b u(x)v'(x) \, dx = [u(x)v(x)]_a^b - \int_a^b u'(x)v(x) \, dx. \quad (2.24)$$

例如，取 $u(x) = x$ 、 $v'(x) = e^x$ ，得到 $\int_0^1 xe^x \, dx = [xe^x]_0^1 - \int_0^1 e^x \, dx = 1$ 。边界项不能无故删除；只有在函数于边界消失、区域无边界，或衰减速度足以使无穷远边界项趋零时才能省略。更一般地，若 u, v 绝对连续，公式仍成立，此时导数按几乎处处意义理解。

2.7.3 路径积分和散度定理连接局部变化与整体边界

设分段连续可微路径 $\gamma : [a, b] \rightarrow \mathbb{R}^d$ 。对沿路径连续的标量函数 $h : \mathbb{R}^d \rightarrow \mathbb{R}$ ，标量线积分定义为

$$\int_\gamma h \, ds = \int_a^b h(\gamma(t)) \|\gamma'(t)\|_2 \, dt.$$

速度的范数把参数增量换成弧长，因此反转路径方向不改变该积分。对沿路径连续的向量场 $\mathbf{F} : \mathbb{R}^d \rightarrow \mathbb{R}^d$ ，向量场线积分则定义为

$$\int_\gamma \mathbf{F} \cdot d\mathbf{r} = \int_a^b \mathbf{F}(\gamma(t))^\top \gamma'(t) \, dt.$$

若 $\mathbf{F} = \nabla \phi$ 且 ϕ 连续可微，链式法则给出

$$\int_\gamma \nabla \phi \cdot d\mathbf{r} = \phi(\gamma(b)) - \phi(\gamma(a)). \quad (2.25)$$

因此梯度场的路径积分只依赖端点。向量场线积分在路径方向反转时变号；若漏掉参数化导数 $\gamma'(t)$ ，就会丢失方向和行进速度的信息。

对具有分段光滑边界的有界区域 $\Omega \subset \mathbb{R}^d$ ，若向量场 $\mathbf{F}$ 在 $\overline{\Omega}$ 的一个开邻

域内连续可微，**散度定理** (divergence theorem) 写成

$$\int_{\Omega} \nabla \cdot \mathbf{F} \, d\mathbf{x} = \int_{\partial\Omega} \mathbf{F}^{\top} \mathbf{n} \, dS, \quad (2.26)$$

其中 $\mathbf{n}$ 是外法向量。左边汇总区域内部的局部流出率，右边计算穿过边界的净通量。它的严格适用条件随区域与函数空间版本而异；带尖点、无界区域或弱导数时，需要使用相应推广并重新核对边界项。分部积分、路径积分与散度定理共同说明，局部导数进入整体积分时，通常会留下不可忽略的边界信息。

2.8 极限与积分的交换

2.8.1 逐点收敛不足以控制积分

在 $(0, 1)$ 上令

$$f_n(x) = n \mathbb{I}_{(0, 1/n)}(x).$$

对每个固定 $x > 0$ ，充分大的 n 满足 $x \geq 1/n$ ，故 $f_n(x) \rightarrow 0$ ；然而

$$\int_0^1 f_n(x) \, dx = 1$$

对所有 n 成立。因此 $\lim_n \int f_n \neq \int \lim_n f_n$ 。峰越来越窄，却同时越来越高，逐点观察不到被压缩区域中保留下来的总质量。要交换极限与积分，必须阻止这种质量逃逸或集中²。

² G. B. Folland, *Real Analysis: Modern Techniques and Their Applications*, Wiley, 1999, 2nd ed.

2.8.2 单调收敛允许非负质量逐步增加

定理 2.7 单调收敛定理 设 $f_n, f : X \rightarrow [0, \infty]$ 可测, 且 $f_n(x) \uparrow f(x)$ 几乎处处, 则

$$\lim_{n \rightarrow \infty} \int_X f_n \, d\mu = \int_X f \, d\mu.$$

两边都允许取 $+\infty$ 。

证明. 把单调性或收敛关系失效的可测零测集并为 N ，并将 f_n 与 f 在 N 上都改为 0。修改后的函数仍可测且积分不变，所以可假定 $f_n \uparrow f$ 逐点成立。由 $0 \leq f_n \leq f$ ，积分序列单调不减且

$$L := \lim_{n \rightarrow \infty} \int f_n \, d\mu \leq \int f \, d\mu.$$

还需证明反向不等式。任取满足 $0 \leq s \leq f$ 的简单函数，将它写为 $s =$

$\sum_{j=1}^m a_j \mathbb{I}_{E_j}$, 其中 $a_j > 0$ 且 E_j 两两不交。固定 $c \in (0, 1)$, 定义

$$E_{j,n} = E_j \cap \{x : f_n(x) \geq ca_j\}.$$

由于 $f_n \uparrow f$ 且 $f \geq a_j$ 于 E_j , 有 $E_{j,n} \uparrow E_j$ 。测度对递增集合连续, 故 $\mu(E_{j,n}) \uparrow \mu(E_j)$ 。同时

$$f_n \geq c \sum_{j=1}^m a_j \mathbb{I}_{E_{j,n}},$$

从而

$$L \geq \lim_{n \rightarrow \infty} c \sum_{j=1}^m a_j \mu(E_{j,n}) = c \int s \, d\mu.$$

先令 $c \uparrow 1$, 再对所有 $0 \leq s \leq f$ 的简单函数取上确界。根据非负积分的定义 (2.21), $L \geq \int f \, d\mu$ 。与前一不等式合并即得结论。 ■

非负性避免正负无穷相消, 单调性则保证已经积累的质量不会在后续消失。定理不要求存在一个可积的统一上界, 也不要求各 $\int f_n$ 有限。

2.8.3 Fatou 引理保留下极限方向的不等式

对扩展实数列 (a_n) , 尾部下确界 $\inf_{k \geq n} a_k$ 随 n 单调不减, 尾部上确界 $\sup_{k \geq n} a_k$ 随 n 单调不减。因此可在扩展实数中定义

$$\liminf_{n \rightarrow \infty} a_n = \lim_{n \rightarrow \infty} \inf_{k \geq n} a_k, \quad \limsup_{n \rightarrow \infty} a_n = \lim_{n \rightarrow \infty} \sup_{k \geq n} a_k.$$

函数列的下极限与上极限按每个 x 逐点定义。若 a_n 收敛, 则二者都等于通常极限; 若不收敛, 它们分别记录尾部最终能够达到的下界与上界。

引理 2.8 Fatou 引理 若 $f_n : X \rightarrow [0, \infty]$ 可测, 则

$$\int_X \liminf_{n \rightarrow \infty} f_n \, d\mu \leq \liminf_{n \rightarrow \infty} \int_X f_n \, d\mu. \quad (2.27)$$

证明. 令 $g_n = \inf_{k \geq n} f_k$ 。则 g_n 可测, $0 \leq g_n \uparrow \liminf_k f_k$ 。由单调收敛定理,

$$\int \liminf_k f_k \, d\mu = \lim_{n \rightarrow \infty} \int g_n \, d\mu.$$

对每个 $k \geq n$ 都有 $g_n \leq f_k$, 故

$$\int g_n \, d\mu \leq \inf_{k \geq n} \int f_k \, d\mu.$$

令 $n \rightarrow \infty$ 便得到式 (2.27)。 ■

Fatou 引理通常只给一个方向, 因为积分可能在极限中损失质量。对上述收缩峰 f_n , 左边为 0, 右边为 1, 不等式严格成立。

2.8.4 支配收敛用一个可积函数统一控制

定理 2.9 支配收敛定理 设 $f_n, f : X \rightarrow \mathbb{R}$ 可测, $f_n \rightarrow f$ 几乎处处, 并且存在非负可积函数 g 使 $|f_n| \leq g$ 几乎处处对所有 n 成立, 则 f 可积, 而且

$$\lim_{n \rightarrow \infty} \int_X f_n d\mu = \int_X f d\mu.$$

此外, $\int |f_n - f| d\mu \rightarrow 0$ 。

证明. 把收敛或控制条件失效的可测零测集的可数并记为 N , 并将 f_n, f, g 在 N 上都改为 0。这些函数仍可测且积分不变, 因而下述关系可以按逐点意义使用。由 $|f_n| \leq g$ 并取逐点极限可得 $|f| \leq g$ 几乎处处, 所以 f 可积。函数 $g + f_n$ 与 $g - f_n$ 均非负。对它们分别使用 Fatou 引理,

$$\begin{aligned} \int g + \int f &\leq \int g + \liminf_{n \rightarrow \infty} \int f_n, \\ \int g - \int f &\leq \int g - \limsup_{n \rightarrow \infty} \int f_n. \end{aligned}$$

由于 $\int g < \infty$, 可以从两边减去它, 得到

$$\int f \leq \liminf_n \int f_n \leq \limsup_n \int f_n \leq \int f.$$

故积分收敛到 $\int f$ 。

最后, $|f_n - f| \rightarrow 0$ 几乎处处, 且 $|f_n - f| \leq 2g$ 。再对非负函数 $|f_n - f|$ 应用刚证明的积分交换结论, 得到 $\int |f_n - f| d\mu \rightarrow 0$ 。 ■

收缩峰 $f_n = n\mathbb{1}_{(0,1/n)}$ 不存在满足条件的可积控制函数。事实上, 若 $g \geq f_n$ 对所有 n 成立, 则对接近 0 的 x 可选 n 约为 $1/x$, 迫使 $g(x)$ 至少具有 $1/x$ 量级, 而它在 0 附近不可积。这个例子精确指出失效的是统一可积控制, 而不是逐点极限。

2.8.5 Tonelli 与 Fubini 控制积分次序

定理 2.10 Tonelli 与 Fubini 定理 设 $(X, \mathcal{A}, \mu)$ 与 $(Y, \mathcal{B}, \nu)$ 为 σ 有限测度空间, 且 $f : X \times Y \rightarrow \overline{\mathbb{R}}$ 对乘积 σ 代数可测。

- 若 $f \geq 0$, 则每个截面 $y \mapsto f(x, y)$ 与 $x \mapsto f(x, y)$ 都可测, 并且两

个内层积分函数

$$x \mapsto \int_Y f(x, y) d\nu(y), \quad y \mapsto \int_X f(x, y) d\mu(x)$$

分别关于 x 与 y 可测, 且

$$\begin{aligned} \int_{X \times Y} f d(\mu \otimes \nu) &= \int_X \left(\int_Y f(x, y) d\nu(y) \right) d\mu(x) \\ &= \int_Y \left(\int_X f(x, y) d\mu(x) \right) d\nu(y). \end{aligned}$$

允许共同值为 $+\infty$ 。这是 Tonelli 定理。

- 若 $\int_{X \times Y} |f| d(\mu \otimes \nu) < \infty$, 则 $y \mapsto f(x, y)$ 对几乎每个 x 可积, $x \mapsto f(x, y)$ 对几乎每个 y 可积。把相应内层积分函数在例外集上置为 0 后, 它们分别可积, 上述等式对 f 成立并取有限值。这是 Fubini 定理。

证明路线与本节前面的构造一致。先对矩形指示函数 $\mathbb{I}_{A \times B}$ 核对等式, 两边都等于 $\mu(A)\nu(B)$, 再由有限可加性推广到有限个矩形生成的代数。随后在有限测度块上使用单调类定理, 把结论推广到乘积 σ 代数中的一般可测集合; σ 有限性允许用递增的有限测度块覆盖整个乘积空间。至此, 结论对任意乘积可测集合的指示函数成立, 再由线性性推广到非负简单函数。任意非负可测 f 可取简单函数 $s_n \uparrow f$, 三处积分分别使用单调收敛定理, 便得到 Tonelli 定理。若 f 绝对可积, 对 f^+ 与 f^- 分别应用 Tonelli; $|f|$ 的积分有限保证两部分的累次积分几乎处处有限, 二者相减得到 Fubini 定理。

这里非负性允许无穷值, 绝对可积性则排除了依赖积分次序的条件相消。例如在 $\mathbb{N} \times \mathbb{N}$ 上使用计数测度时, Tonelli 说明非负双重级数可以任意交换求和次序; Fubini 说明绝对收敛的双重级数也可以这样做。若既不非负也不绝对可积, 交换次序可能改变结果, 甚至一个次序收敛而另一个发散。因此“把两个积分换一下”不是排版操作, 而是需要先核对函数符号或绝对积分的数学步骤。

2.9 隐式求导与参数积分

2.9.1 方程也能在局部定义函数

显式关系 $y = \varphi(x)$ 直接给出输入如何映射到输出, 方程 $F(x, y) = 0$ 却只规定二者必须共同满足的约束。例如 $F(x, y) = y^2 - x = 0$ 在 $x > 0$ 附近有 $y = \sqrt{x}$ 和 $y = -\sqrt{x}$ 两支, 若不先指定所考察的解, 方程并不定义唯一函

数。更糟的是，在 $(x, y) = (0, 0)$ 附近，两支相交且 $\partial F / \partial y = 2y = 0$ ，不能把 y 稳定地看作 x 的可微函数。

下面的存在性证明需要用导数控制有限位移。对矩阵 $\mathbf{A} \in \mathbb{R}^{s \times r}$ ，由欧氏范数诱导的算子范数（induced operator norm）定义为

$$\|\mathbf{A}\|_{\text{op}} = \sup_{\mathbf{h} \neq \mathbf{0}} \frac{\|\mathbf{A}\mathbf{h}\|_2}{\|\mathbf{h}\|_2} = \sup_{\|\mathbf{h}\|_2=1} \|\mathbf{A}\mathbf{h}\|_2.$$

它表示线性映射对向量长度的最大放大倍数，定义立即给出 $\|\mathbf{A}\mathbf{h}\|_2 \leq \|\mathbf{A}\|_{\text{op}} \|\mathbf{h}\|_2$ 。若连续可微映射 G 的定义域包含 $\mathbf{y}'$ 到 $\mathbf{y}$ 的线段，中值积分公式进一步给出

$$\|G(\mathbf{y}) - G(\mathbf{y}')\|_2 \leq \sup_{0 \leq t \leq 1} \left\| \mathbf{D}G(\mathbf{y}' + t(\mathbf{y} - \mathbf{y}')) \right\|_{\text{op}} \|\mathbf{y} - \mathbf{y}'\|_2. \quad (2.28)$$

因此，邻域内统一的导数范数上界会直接变成 Lipschitz 常数；若该上界小于 1，就得到后文所需的压缩条件。

定理 2.11 隐函数定理 设 $F : \mathbb{R}^p \times \mathbb{R}^m \rightarrow \mathbb{R}^m$ 在 $(\mathbf{a}, \mathbf{b})$ 的某个开邻域内连续可微， $F(\mathbf{a}, \mathbf{b}) = \mathbf{0}$ ，并且关于待解变量的 Jacobian 矩阵

$$\mathbf{D}_{\mathbf{y}}F(\mathbf{a}, \mathbf{b}) \in \mathbb{R}^{m \times m}$$

可逆。则存在 $\mathbf{a}$ 与 $\mathbf{b}$ 的邻域 U, V ，以及唯一的连续可微函数 $\varphi : U \rightarrow V$ ，使 $\varphi(\mathbf{a}) = \mathbf{b}$ ，并且对所有 $(\mathbf{x}, \mathbf{y}) \in U \times V$ 都有

$$F(\mathbf{x}, \mathbf{y}) = \mathbf{0} \iff \mathbf{y} = \varphi(\mathbf{x}).$$

其 Jacobian 矩阵满足

$$\mathbf{D}\varphi(\mathbf{x}) = -[\mathbf{D}_{\mathbf{y}}F(\mathbf{x}, \varphi(\mathbf{x}))]^{-1} \mathbf{D}_{\mathbf{x}}F(\mathbf{x}, \varphi(\mathbf{x})). \quad (2.29)$$

存在性、局部唯一性和可微性都需要证明，不能由形式求导代替。第 2.12 节建立压缩映射后将补全证明。先假定定理给出的 φ 已经存在，对恒等式 $F(\mathbf{x}, \varphi(\mathbf{x})) = \mathbf{0}$ 应用链式法则，得到

$$\mathbf{D}_{\mathbf{x}}F + \mathbf{D}_{\mathbf{y}}F \mathbf{D}\varphi = \mathbf{0}.$$

左乘 $\mathbf{D}_{\mathbf{y}}F$ 的逆即得式 (2.29)。乘法次序由矩阵维度决定，不能把逆矩阵随意移到右侧。

2.9.2 驻点方程给出最优解的局部变化

考虑依赖参数 θ 的无约束目标 $q(z, \theta)$ 。若局部最优解 $z^*(\theta)$ 位于定义域内部，它满足驻点方程

$$F(\theta, z) = \frac{\partial q}{\partial z}(z, \theta) = 0.$$

若 q 二阶连续可微，且 $\partial^2 q / \partial z^2$ 在所考察解处非零，隐函数定理给出该驻点的局部唯一分支。这并不自动说明它是全局最优解；还要由曲率或其他结构核对最优性。

示例 2.12 参数二次目标中的解导数与包络导数 对 $\theta > -1$ ，令

$$q(z, \theta) = \frac{1}{2}(1 + \theta)z^2 - \theta z.$$

因为 $\partial^2 q / \partial z^2 = 1 + \theta > 0$ ，目标严格凸，唯一驻点就是全局最小点。驻点方程为

$$F(\theta, z) = (1 + \theta)z - \theta = 0.$$

隐式求导给出

$$\frac{dz^*}{d\theta} = -\frac{\partial F / \partial \theta}{\partial F / \partial z} = -\frac{z^* - 1}{1 + \theta}.$$

直接消元得到

$$z^*(\theta) = \frac{\theta}{1 + \theta}, \quad \frac{dz^*}{d\theta} = \frac{1}{(1 + \theta)^2},$$

两种计算一致。

最优值 $V(\theta) = q(z^*(\theta), \theta)$ 的链式求导为

$$V'(\theta) = \frac{\partial q}{\partial z} \frac{dz^*}{d\theta} + \frac{\partial q}{\partial \theta}.$$

在内部驻点，第一项因 $\partial q / \partial z = 0$ 消失，所以

$$V'(\theta) = \left. \frac{\partial q}{\partial \theta} \right|_{z=z^*(\theta)} = \frac{1}{2}(z^*)^2 - z^*. \quad (2.30)$$

另一方面，直接代回可得

$$V(\theta) = -\frac{\theta^2}{2(1 + \theta)}, \quad V'(\theta) = -\frac{\theta(\theta + 2)}{2(1 + \theta)^2},$$

与式 (2.30) 一致。

式 (2.30) 体现了**包络定理** (envelope theorem) 的基本机制：最优值的一阶变化不需要显式乘上最优解导数，因为目标对决策变量的一阶导数在内部最优处为零。但解导数本身并未消失；若关心参数变化后 z^* 怎样移

动, 仍要使用隐式求导。边界解、不可微目标、多重最优解或受约束问题不能直接套用这个简单版本, 后续最优化章节会加入相应条件。

2.9.3 积分号下求导需要统一可积控制

设

$$G(\theta) = \int_X g(x, \theta) d\mu(x).$$

形式上希望把导数移入积分号:

$$G'(\theta) \stackrel{?}{=} \int_X \frac{\partial g}{\partial \theta}(x, \theta) d\mu(x).$$

真正需要交换的是差商的极限与积分。固定 θ_0 , 设对每个 $\theta \in I, x \mapsto g(x, \theta)$ 可测, 其中 I 是 θ_0 的一个开邻域, 并且 $g(\cdot, \theta_0)$ 可积。若对几乎处处的 x , $\theta \mapsto g(x, \theta)$ 在 I 内可微, 偏导数关于 x 可测, 并且存在可积函数 h 使

$$\left| \frac{\partial g}{\partial \theta}(x, \theta) \right| \leq h(x) \quad \text{对几乎处处的 } x \text{ 及所有 } \theta \in I \text{ 成立}, \quad (2.31)$$

那么中值定理把差商的绝对值也控制在 $h(x)$ 之下。差商逐点收敛到 $\partial g / \partial \theta(x, \theta_0)$, 支配收敛定理于是给出

$$G'(\theta_0) = \int_X \frac{\partial g}{\partial \theta}(x, \theta_0) d\mu(x). \quad (2.32)$$

条件 (2.31) 是一个便于核对的充分条件; 更一般的版本可以直接控制差商, 或使用其他一致可积条件。

示例 2.13 参数积分中的控制函数失效 下面考察参数域边界处对应的右求导问题。对 $\theta \geq 0$ 与 $x \in (0, 1)$, 定义

$$g(x, \theta) = \begin{cases} \frac{\theta x}{x^2 + \theta^2}, & \theta > 0, \\ 0, & \theta = 0. \end{cases}$$

每个固定 $x > 0$ 处关于 θ 的右偏导数都等于 $1/x$, 但 $1/x$ 在 $(0, 1)$ 上不可积。直接积分得到

$$G(\theta) = \frac{\theta}{2} \log \left(\frac{1 + \theta^2}{\theta^2} \right) \quad (\theta > 0), \quad G(0) = 0.$$

于是 $G(\theta)/\theta$ 在 $\theta \downarrow 0$ 时发散, G 在 0 处没有有限右导数。积分内的逐点右导数虽然存在, 却缺少统一可积控制; 因此这里不能交换右求导与积分。

2.10 非光滑与人为替代梯度

2.10.1 不可微点与几乎处处可导是不同陈述

函数 $|x|$ 在 $x \neq 0$ 处导数为 $\text{sign}(x)$ ，在 0 处左右导数不同。ReLU 函数 $\max\{0, x\}$ 也只在 0 处不可微。由于单点是 Lebesgue 零测集，它们都几乎处处可导，但“几乎处处有导数”并没有为例外点指定导数值。

阈值函数 $\mathbb{I}\{x \geq 0\}$ 在 $x \neq 0$ 处导数为 0，在 0 处不连续且不可微。若机械地使用几乎处处导数，反向传播得到的信号几乎处处为零，这无法表达跨过阈值会改变输出。重置、取整和离散选择也有类似问题：前向映射的真实局部导数可能不存在或不能提供有用方向。

凸函数的不可微点可以用凸次梯度处理，其正式定义与最优性条件见第 3.9 节。凸次梯度依赖全局仿射下界，并非“随便给不可微点填一个导数”；对于一般非凸函数，还需要区分其他广义导数概念。

有限维**局部 Lipschitz 函数**是在每个点附近都满足某个 Lipschitz 界的函数。Rademacher 定理说明，这类函数几乎处处可微，但定理仍没有为例外点指定唯一梯度。一种适用于局部 Lipschitz 函数的扩展是**Clarke 广义梯度**（Clarke generalized gradient）：

$$\partial^\circ f(\mathbf{x}) = \overline{\text{conv}} \left\{ \lim_{k \rightarrow \infty} \nabla f(\mathbf{x}_k) : \mathbf{x}_k \rightarrow \mathbf{x}, f \text{ 在 } \mathbf{x}_k \text{ 处可微, 且该极限存在} \right\}.$$

这里 conv 表示有限个非负权重和为 1 的凸组合，横线表示再取闭包。对局部 Lipschitz 凸函数，Clarke 广义梯度与第 3.9 节定义的凸次梯度集合一致；对一般非凸局部 Lipschitz 函数，前者仍由邻近可微点的梯度极限构造，不再表示全局仿射下界。阈值函数在跳点附近不连续，因而不是局部 Lipschitz 函数，不能直接套用这一构造。

2.10.2 替代梯度是反向计算规则

在含阈值或脉冲事件的模型中，常保留离散前向映射，却在反向计算时将其导数替换成某个平滑且非零的函数。这种信号称为**替代梯度**（surrogate gradient）。它是算法人为指定的近似更新方向，不自动等于前向映射的经典导数，也通常不满足凸次梯度的不等式。因此使用时应分别写清前向函数、反向替代函数及其尺度，不能把训练规则描述成对原离散函数的精确求导。

中心差分

$$\frac{f(x + \varepsilon) - f(x - \varepsilon)}{2\varepsilon}$$

只能检验实际代入的函数 f 在尺度 ε 附近怎样变化。若程序反向传播使用替代梯度，而数值差分计算离散前向函数，两者本来就不是同一个导数对

象；不一致不必然说明程序实现错误。

2.10.3 函数值逼近不保证导数逼近

用平滑函数

$$f_\varepsilon(x) = \sqrt{x^2 + \varepsilon^2}, \quad \varepsilon > 0$$

逼近 $|x|$ 。由

$$0 \leq f_\varepsilon(x) - |x| = \frac{\varepsilon^2}{\sqrt{x^2 + \varepsilon^2} + |x|} \leq \varepsilon,$$

可知 f_ε 在整个 $\mathbb{R}$ 上一致收敛到 $|x|$ 。其导数为

$$f'_\varepsilon(x) = \frac{x}{\sqrt{x^2 + \varepsilon^2}}.$$

对每个 $x \neq 0$, 导数收敛到 $\text{sign}(x)$; 在 $x = 0$ 处始终为 0, 而 $|x|$ 在那里没有导数。即使人为规定 $\text{sign}(0) = 0$, 导数收敛也不一致。例如取 $x_\varepsilon = \varepsilon^2 > 0$, 则

$$f'_\varepsilon(x_\varepsilon) = \frac{\varepsilon}{\sqrt{1 + \varepsilon^2}} \longrightarrow 0, \quad \text{sign}(x_\varepsilon) = 1.$$

因此两者之差趋于 1, 不可能一致收敛。所以函数值的一致逼近不能推出导数的一致逼近。讨论光滑近似时, 必须明确控制的是函数值、导数还是积分误差。

2.11 函数收敛与本质界

2.11.1 同一函数列可以在不同误差尺度下得到不同结论

设 $f_n, f : X \rightarrow \mathbb{R}$ 。逐点收敛允许开始稳定的时刻依赖输入:

$$\forall x, \quad |f_n(x) - f(x)| \rightarrow 0.$$

一致收敛要求一个 n 同时控制所有输入:

$$\|f_n - f\|_\infty := \sup_{x \in X} |f_n(x) - f(x)| \longrightarrow 0. \quad (2.33)$$

在测度空间上, L^p 收敛则控制平均的 p 次误差:

$$\|f_n - f\|_p := \left(\int_X |f_n - f|^p d\mu \right)^{1/p} \longrightarrow 0, \quad 1 \leq p < \infty. \quad (2.34)$$

在 $[0, 1]$ 上取 $f_n(x) = x^n$ 。它逐点收敛到

$$f(x) = \begin{cases} 0, & 0 \leq x < 1, \\ 1, & x = 1. \end{cases}$$

但收敛不一致, 因为对每个 n , $\sup_{0 \leq x < 1} x^n = 1$ 。另一方面, 对任意有限 $p \geq 1$,

$$\|f_n - f\|_p^p = \int_0^1 x^{np} dx = \frac{1}{np+1} \rightarrow 0.$$

同一函数列因此逐点且在每个有限 L^p 意义下收敛, 却不一致收敛。区别来自最坏输入与平均误差采用了不同尺度。

若 $\mu(X) < \infty$, 一致收敛蕴含 L^p 收敛, 因为

$$\|f_n - f\|_p \leq \mu(X)^{1/p} \|f_n - f\|_\infty.$$

当空间测度无穷时, 这个推论可能失败; 常数函数 $f_n = 1/n$ 在 $\mathbb{R}$ 上一致趋于 0, 但它甚至不属于有限 p 的 $L^p(\mathbb{R})$ 。

2.11.2 本质上确界忽略零测例外

普通上确界会被单个异常点改变, 而保持可测性的零测集修改不影响积分。可测函数 f 的 **本质上确界** (essential supremum) 定义为

$$\operatorname{ess\,sup}_{x \in X} |f(x)| = \inf\{M \geq 0 : |f(x)| \leq M \text{ 几乎处处}\}.$$

由此定义

$$\|f\|_{L^\infty} = \operatorname{ess\,sup}_{x \in X} |f(x)|. \quad (2.35)$$

例如在 $[0, 1]$ 上令 $f(0) = 100$ 、其余位置 $f(x) = 0$, 则普通上确界为 100, 本质上确界却为 0。

对 $1 \leq p < \infty$, 式 (2.34) 中的表达式满足齐次性和三角不等式, 但若只把逐点不同的函数当作不同对象, $\|f\|_p = 0$ 仍不能推出 f 处处为零。为得到真正的范数空间, 定义

$$f \sim g \iff f = g \text{ 几乎处处},$$

并把 L^p 定义为可测函数按此关系形成的等价类。 L^∞ 也采用同样约定。这与所有有界函数上的普通上确界范数不同: 后者区分单点修改, 前者不区分。当 $0 < p < 1$ 时, 同一积分表达式仍可用来度量误差大小, 但通常不满足三角不等式, 所以不是范数; 本章不把这一区间记作范数空间。

2.11.3 误差尺度必须与问题中的分布和函数类对应

一个固定函数序列的一致收敛，讨论的是 n 增大时对所有输入能否共同控制。统计学习中“经验平均一致逼近总体平均”通常还要对候选函数类取上确界，控制对象形如

$$\sup_{f \in \mathcal{F}} \left| \frac{1}{n} \sum_{i=1}^n f(X_i) - \int f \, dP \right|.$$

这里的一致性针对候选函数 $f \in \mathcal{F}$ ，不是本节式 (2.33) 中针对输入 $x \in X$ 的一致收敛。两者都出现上确界，却不能混为同一概念。

几乎处处和 L^p 范数还依赖所选测度。若 Q 对 P **绝对连续** (absolutely continuous)，记作 $Q \ll P$ ，则 $P(A) = 0$ 蕴含 $Q(A) = 0$ ，原来 P 意义下的零测例外在 Q 下仍可忽略。若没有 $Q \ll P$ ，换分布可能给原零测集正质量。例如 P 是 $[0, 1]$ 上的均匀分布， Q 把全部质量放在 0 点；两个只在 0 处不同的函数在 P 意义下等价，在 Q 意义下却可能具有完全不同的误差。

2.12 完备空间与压缩映射定理

2.12.1 完备性保证柯西极限留在空间内

度量空间 (X, d) 若每个柯西数列都收敛到 X 中的点，就称为**完备** (complete)。实数空间与有限维欧氏空间完备，有理数空间在通常距离下不完备。完备性不是说每个序列都收敛，而是说只要序列内部已经表现出应有的趋近性质，其极限不会落到空间外。

令 S 为任意非空集合， $\mathcal{B}(S)$ 为所有有界实函数 $S \rightarrow \mathbb{R}$ 的集合，配备普通上确界范数

$$\|f\|_\infty = \sup_{x \in S} |f(x)|.$$

这个空间完备。事实上，若 (f_n) 在上确界范数下为柯西列，则对每个固定 x ， $(f_n(x))$ 是实柯西列，故存在 $f(x) = \lim_n f_n(x)$ 。取一个 n_0 使 $\|f_n - f_{n_0}\|_\infty \leq 1$ 对所有充分大的 n 成立，再令 $n \rightarrow \infty$ ，得到 $|f(x)| \leq |f_{n_0}(x)| + 1$ ，所以 f 有界。最后，对任意 $\varepsilon > 0$ ，选 N 使 $m, n \geq N$ 时 $\|f_m - f_n\|_\infty < \varepsilon$ 。固定 $n \geq N$ 并令 $m \rightarrow \infty$ ，对所有 x 都有 $|f(x) - f_n(x)| \leq \varepsilon$ ，于是 $\|f - f_n\|_\infty \leq \varepsilon$ 。这证明 f_n 在该空间中收敛到 f 。

空间 L^∞ 也完备，但其元素是几乎处处等价类，范数是式 (2.35)。上面的逐点证明不能原封不动搬过去，因为不同 n 的代表函数可能各自在不同零测集上修改；严格证明需要先统一这些例外集合。

2.12.2 压缩映射把距离按固定比例缩短

映射 $T : X \rightarrow X$ 若存在 $q \in [0, 1)$ 使

$$d(Tx, Ty) \leq qd(x, y) \quad \text{对所有 } x, y \in X, \quad (2.36)$$

就称为**压缩映射** (contraction mapping)。关键是同一个 $q < 1$ 在整个所考察空间上成立, 并且 T 确实把 X 映回自身³。

³ J. B. Conway, *A Course in Functional Analysis*, Springer, 1990, 2nd ed.

定理 2.14 Banach 压缩映射定理 设 (X, d) 是非空完备度量空间, $T : X \rightarrow X$ 为压缩映射, 压缩因子为 $q < 1$ 。则 T 有唯一不动点 $x^* \in X$ 。从任意 $x^{(0)} \in X$ 出发定义 $x^{(n+1)} = T(x^{(n)})$, 都有 $x^{(n)} \rightarrow x^*$, 并且

$$d(x^{(n)}, x^*) \leq \frac{q^n}{1-q} d(x^{(1)}, x^{(0)}), \quad (2.37)$$

$$d(x^{(n)}, x^*) \leq \frac{q}{1-q} d(x^{(n)}, x^{(n-1)}) \quad (n \geq 1). \quad (2.38)$$

证明. 反复使用压缩条件可得

$$d(x^{(n+1)}, x^{(n)}) \leq q^n d(x^{(1)}, x^{(0)}).$$

对 $m > n$, 三角不等式和几何级数给出

$$\begin{aligned} d(x^{(m)}, x^{(n)}) &\leq \sum_{k=n}^{m-1} d(x^{(k+1)}, x^{(k)}) \\ &\leq d(x^{(1)}, x^{(0)}) \sum_{k=n}^{m-1} q^k \\ &\leq \frac{q^n}{1-q} d(x^{(1)}, x^{(0)}). \end{aligned}$$

右边随 $n \rightarrow \infty$ 趋于零, 所以 $(x^{(n)})$ 是柯西数列。完备性保证存在 $x^* \in X$ 使 $x^{(n)} \rightarrow x^*$ 。压缩条件还蕴含 T 为 Lipschitz 连续, 因此

$$T(x^*) = T\left(\lim_n x^{(n)}\right) = \lim_n T(x^{(n)}) = \lim_n x^{(n+1)} = x^*.$$

故 x^* 是不动点。

若 y^* 也是不动点, 则

$$d(x^*, y^*) = d(Tx^*, Ty^*) \leq qd(x^*, y^*).$$

因为 $q < 1$, 只能有 $d(x^*, y^*) = 0$, 故不动点唯一。

在上面的柯西界中令 $m \rightarrow \infty$, 便得式 (2.37)。若从第 $n-1$ 步重新计算

同一界,

$$d(x^{(n)}, x^*) \leq \sum_{k=n}^{\infty} d(x^{(k+1)}, x^{(k)}) \leq d(x^{(n)}, x^{(n-1)}) \sum_{j=1}^{\infty} q^j,$$

便得到式 (2.38)。 ■

这个证明同时说明存在、唯一和可计算的误差界各来自哪里：几何尾和使迭代为柯西列，完备性把极限留在空间中，连续性使极限成为不动点，严格的 $q < 1$ 保证唯一性。若只允许 $q = 1$ ，结论都可能丢失。恒等映射 $T(x) = x$ 有无穷多个不动点； $T(x) = x + 1$ 在 $\mathbb{R}$ 上没有不动点，且相应迭代发散。非扩张并不等于压缩。完备性也不能省略。在非完备空间 $X = (0, 1)$ 上，映射 $T(x) = x/2$ 是压缩因子为 $1/2$ 的自映射，但它唯一的不动点是被排除的 0 。从任意 $x^{(0)} \in X$ 出发，迭代 $x^{(n)} = x^{(0)}/2^n$ 在 $\mathbb{R}$ 中趋于 0 ，却不在 X 中收敛。

2.12.3 压缩迭代补全隐函数的局部存在证明

现在回到定理 2.11。记

$$A = D_y F(a, b), \quad T_x(y) = y - A^{-1} F(x, y).$$

$F(x, y) = 0$ 当且仅当 y 是 T_x 的不动点。并且

$$D_y T_x(y) = I - A^{-1} D_y F(x, y),$$

它在 (a, b) 处为零。由导数连续性，可以选择闭球 $B = \{y : \|y - b\|_2 \leq r\}$ 和 a 的邻域 U ，使

$$\sup_{x \in U, y \in B} \|D_y T_x(y)\|_{\text{op}} \leq q < 1. \quad (2.39)$$

沿 y 方向使用式 (2.28) 可知，每个 T_x 在 B 上都是同一因子 q 的压缩映射。

还必须核对自映射。因为 $T_a(b) = b$ 且 $T_x(b)$ 关于 x 连续，可进一步缩小 U ，使

$$\|T_x(b) - b\|_2 \leq \frac{1-q}{2} r.$$

于是对 $y \in B$,

$$\|T_x(y) - b\|_2 \leq q \|y - b\|_2 + \frac{1-q}{2} r \leq \frac{1+q}{2} r < r.$$

所以 $T_x(B)$ 包含在 B 的内部 V 中。闭球 B 在有限维欧氏空间中完备, Banach 定理便对每个 $x \in U$ 给出唯一不动点 $\varphi(x) \in V$ 。若 $(x, y) \in U \times V$ 且 $F(x, y) = 0$ ，则 $y \in B$ 也是 T_x 的不动点，唯一性迫使 $y = \varphi(x)$ 。这证明

了定理所述的局部存在与零点集合的逐点唯一性。

还需说明所得解随参数连续可微。对 $\mathbf{x}, \mathbf{x}' \in U$ ，在更小的紧邻域内， $T_{\mathbf{x}}(\mathbf{y})$ 关于 $\mathbf{x}$ 的导数有统一上界 L 。利用两个不动点关系，

$$\|\varphi(\mathbf{x}) - \varphi(\mathbf{x}')\|_2 \leq q\|\varphi(\mathbf{x}) - \varphi(\mathbf{x}')\|_2 + L\|\mathbf{x} - \mathbf{x}'\|_2,$$

故 φ 局部 Lipschitz 连续。令 $\mathbf{h} \rightarrow \mathbf{0}$ 并记 $\mathbf{k} = \varphi(\mathbf{x} + \mathbf{h}) - \varphi(\mathbf{x})$ ，前述界给出 $\|\mathbf{k}\|_2 = O(\|\mathbf{h}\|_2)$ 。对恒等式

$$F(\mathbf{x} + \mathbf{h}, \varphi(\mathbf{x}) + \mathbf{k}) - F(\mathbf{x}, \varphi(\mathbf{x})) = \mathbf{0}$$

作一阶展开，得到

$$\mathbf{D}_{\mathbf{x}}F \mathbf{h} + \mathbf{D}_{\mathbf{y}}F \mathbf{k} + o(\|\mathbf{h}\|_2) = \mathbf{0}.$$

邻域取得足够小时， $\mathbf{D}_{\mathbf{y}}F$ 仍可逆，于是

$$\mathbf{k} = -(\mathbf{D}_{\mathbf{y}}F)^{-1}\mathbf{D}_{\mathbf{x}}F \mathbf{h} + o(\|\mathbf{h}\|_2).$$

这证明 φ 可微并给出式 (2.29)；各 Jacobian 矩阵连续又保证 $\mathbf{D}\varphi$ 连续。至此，隐函数定理中的存在、局部唯一与导数公式都已得到说明。证明中特别核对了自映射和统一压缩条件，只有形式上的固定点改写并不足够。

2.13 本章小结

无限过程的核心问题不是“项数足够多”或“变化足够小”，而是误差采用什么尺度、极限是否仍在所考察空间，以及交换运算需要哪些统一控制。数列的柯西条件和空间的完备性回答极限能否留在空间内；紧致性与连续性共同保证极值能够达到；可求和误差比单步误差趋零提供了更强的累计控制。

微分把局部变化组织成线性映射。梯度、Jacobian 矩阵和矩阵梯度分别对应不同输入输出形状，链式法则中的乘积次序由这些形状决定。Hessian 矩阵与二阶 Taylor 展开描述局部曲率，但二阶判据有明确的光滑性、内点和正定性边界。隐函数定理进一步说明，可逆的待解变量 Jacobian 矩阵如何把方程的局部解变成可微函数；最优解导数与最优值的包络导数由此得到区分。

积分把有限加权和推广到测度空间。简单函数从下逼近给出非负积分，正负部分和绝对可积性消除有符号积分的歧义。换元公式、分部积分与散度定理都表明局部微分进入整体积分时会带来体积权重或边界项。单调收敛、Fatou 引理和支配收敛则准确规定极限何时能进入积分号；Tonelli 依靠非负性，Fubini 依靠绝对可积性来交换多重积分次序。

当函数不光滑时，几乎处处导数、凸次梯度、Clarke 广义梯度与人为替代梯度是不同对象。函数值、导数、逐点误差、一致误差和 L^p 误差也不能互相替代；零测例外还依赖当前测度。最后，Banach 压缩映射定理把这些条件落实为可执行的迭代保证：统一压缩产生几何尾和，完备性给出存在，严格压缩给出唯一性，并同时提供误差界。后续章节使用微分、积分或固定点时，应先核对本章列出的定义域、光滑性、可积性、完备性与统一控制条件，再进行形式计算。第 3 章将把这些局部变化、曲率与固定点工具用于最优性条件和求解算法，并区分解的存在、唯一、稳定与可计算性。

第3章

最优化

第2章说明了函数在一点附近怎样变化。本章要把这些局部信息用于一个整体问题：在所有允许的参数中，怎样判断某个参数已经足够好，又怎样逐步找到它？贯穿全章的对象是带正则项的最小二乘

$$F(\mathbf{w}) = \frac{1}{2n} \|\mathbf{X}\mathbf{w} - \mathbf{y}\|_2^2 + \frac{\lambda}{2} \|\mathbf{w}\|_2^2, \quad \mathbf{X} \in \mathbb{R}^{n \times d}, \quad \lambda \geq 0, \quad (3.1)$$

以及线性资源约束

$$\mathbf{A}\mathbf{w} = \mathbf{b}, \quad \mathbf{G}\mathbf{w} \leq \mathbf{h}. \quad (3.2)$$

式(3.1)与第1章的式(1.1)是同一个目标的矩阵写法。正则项限制参数规模，约束则直接排除超出预算的候选；两者看似都在“限制模型”，却改变了不同的数学对象。

本章先区分解、最优性条件与求解算法，再讨论曲率如何决定可以得到何种保证。约束引出乘子、对偶和可核验的证书，非光滑项与不完整梯度则要求改变更新方式。分块、多目标和双层问题不是一条由旧到新的算法路线，而是三种不同的问题组织方式。读完本章，读者应能判断一个优化结论依赖哪些条件，并能指出条件失效时究竟失去了存在性、全局性、唯一性还是收敛速度。

3.1 问题设定与解的性质

一个优化问题必须同时给出目标函数、变量和可行域。记

$$\min_{\mathbf{w} \in C} F(\mathbf{w}), \quad C = \{\mathbf{w} \in \mathbb{R}^d : \mathbf{A}\mathbf{w} = \mathbf{b}, \mathbf{G}\mathbf{w} \leq \mathbf{h}\}.$$

若 $C = \emptyset$ ，问题**不可行** (infeasible)；若 $C \neq \emptyset$ 但 $\inf_{\mathbf{w} \in C} F(\mathbf{w}) = -\infty$ ，问题**无下界** (unbounded below)。只有可行且有有限下界，才值得继续问下确界是否由某个点达到。

全局最优解 (global minimizer) $\mathbf{w}^* \in C$ 满足 $F(\mathbf{w}^*) \leq F(\mathbf{w})$ 对所有 $\mathbf{w} \in C$ 成立。**局部最优解** (local minimizer) 只要求该不等式在 $\mathbf{w}^*$ 的某个邻域内成立。无约束可微问题的**驻点** (stationary point) 满足 $\nabla F(\mathbf{w}) = \mathbf{0}$ 。

驻点只是局部一阶变化消失，可能是极小点、极大点或第 2.5 节所说的微分鞍点。给定 $\varepsilon > 0$ ，若

$$F(\hat{\mathbf{w}}) - \inf_{\mathbf{w} \in C} F(\mathbf{w}) \leq \varepsilon,$$

就称 $\hat{\mathbf{w}}$ 为目标值意义下的 ε 近似解。对无约束可微问题，另一种常见标准是 $\|\nabla F(\hat{\mathbf{w}})\|_2 \leq \varepsilon$ ；在没有额外曲率条件时，这两种近似不能互换。一般约束问题的精确最优点也可能有非零梯度，此时应改用投影梯度、可行方向导数或 KKT 残差等同时反映可行性与驻点性的标准。

若 $C \subseteq \mathbb{R}^d$ 非空且紧， $F : C \rightarrow \mathbb{R}$ 连续，则定理 2.2 保证 F 在 C 上达到全局最小值。这里直接复用第 2 章的极值存在结论。

可行域不紧时，目标本身也可能阻止最小化序列逃向无穷远。若 $\|\mathbf{w}\|_2 \rightarrow \infty$ 时 $F(\mathbf{w}) \rightarrow \infty$ ，称 F 是 **强制的** (coercive)。连续性并不是这里所需的 weakest 条件。**下半连续** (lower semicontinuous) 要求对每个收敛序列 $\mathbf{w}^{(k)} \rightarrow \mathbf{w}$ 都有

$$F(\mathbf{w}) \leq \liminf_{k \rightarrow \infty} F(\mathbf{w}^{(k)}).$$

它允许函数值在极限点向下跳，却不允许极限点的函数值突然高于邻近值。等价地，每个下水平集 $\{\mathbf{w} : F(\mathbf{w}) \leq a\}$ 都是闭集。

设 C 非空且闭， $F : C \rightarrow (-\infty, +\infty]$ 下半连续、强制，并且不恒为 $+\infty$ 且从不取 $-\infty$ 。取 $\bar{\mathbf{w}} \in C$ 使 $F(\bar{\mathbf{w}}) < +\infty$ ，再把最小化序列限制到下水平集

$$K = \{\mathbf{w} \in C : F(\mathbf{w}) \leq F(\bar{\mathbf{w}})\}.$$

若 $\inf_C F = F(\bar{\mathbf{w}})$ ，则 $\bar{\mathbf{w}}$ 已经是最小点；否则 $\inf_C F < F(\bar{\mathbf{w}})$ ，任一最小化序列从某项起都落入 K ，可以只保留这段尾序列。强制性使 K 有界，下半连续性与 C 的闭性使 K 闭，故 K 在有限维空间中紧。该尾序列有子列收敛到 $\mathbf{w}^* \in K$ ，而下半连续性给出 $F(\mathbf{w}^*) \leq \liminf_k F(\mathbf{w}^{(k)}) = \inf_C F$ 。因此下确界达到。这个证明也指出各条件的职责：强制性阻止序列逃向无穷远，闭性保留可行极限，下半连续性把目标值比较传到极限点。当 $\lambda > 0$ 时，式 (3.1) 满足 $F(\mathbf{w}) \geq \lambda \|\mathbf{w}\|_2^2/2$ ，所以即使可行域无界也不会沿参数无穷大的方向降低目标。

存在不等于唯一。若 $\lambda = 0$ 且 $\mathbf{X}$ 有非零空间向量 $\mathbf{v}$ ，那么 $F(\mathbf{w} + t\mathbf{v}) = F(\mathbf{w})$ ，最小点可能形成一条直线。即使唯一，数值问题也可能非常敏感。例如令 $0 < \varepsilon \ll 1$ 并考虑

$$f_b(w_1, w_2) = \frac{1}{2}(\varepsilon w_1^2 + w_2^2) - bw_1.$$

它对每个 b 都有唯一最小点 $(b/\varepsilon, 0)$ ，但 b 改变 Δb 会使第一坐标改变 $\Delta b/\varepsilon$ 。

更一般的二次目标具有如下曲率矩阵：

$$\mathbf{H} = \frac{1}{n} \mathbf{X}^\top \mathbf{X} + \lambda \mathbf{I}$$

当 $\mathbf{H} > \mathbf{0}$ 时，若线性项受到加性扰动 $\delta \mathbf{g}$ ，相应解变化满足

$$\|\delta \mathbf{w}\|_2 \leq \frac{1}{\lambda_{\min}(\mathbf{H})} \|\delta \mathbf{g}\|_2.$$

因此 $1/\lambda_{\min}(\mathbf{H})$ 控制固定尺度加性扰动的绝对放大；经过目标和变量尺度归一化后，条件数 $\kappa(\mathbf{H}) = \lambda_{\max}(\mathbf{H})/\lambda_{\min}(\mathbf{H})$ 才刻画相对病态程度。例如 $\mathbf{H} = \epsilon \mathbf{I}$ 的条件数为 1，但绝对扰动仍会被放大 $1/\epsilon$ 倍。唯一性回答“解有几个”，敏感性还取决于所采用的扰动尺度，不能只由唯一性或条件数笼统判断。

3.2 凸集与凸函数

3.2.1 线段、曲率与全局下界

凸集 (convex set) 包含任意两点之间的整条线段。也就是说，对 $\mathbf{u}, \mathbf{v} \in C$ 和 $\theta \in [0, 1]$ ， $\theta \mathbf{u} + (1 - \theta) \mathbf{v} \in C$ 。线性等式、线性不等式和范数球的解集都是凸集，它们的交集仍为凸集，所以式 (3.2) 定义凸可行域。

定义在凸集 C 上的函数 f 若满足

$$f(\theta \mathbf{u} + (1 - \theta) \mathbf{v}) \leq \theta f(\mathbf{u}) + (1 - \theta) f(\mathbf{v}), \quad (3.3)$$

就称为**凸函数** (convex function)。它的函数图像位于任意弦段下方，因此局部低点不会被更远处的谷底击败¹。

定理 3.1 凸函数的一阶与二阶判据 设 C 为开凸集。可微函数 $f : C \rightarrow \mathbb{R}$ 凸，当且仅当对任意 $\mathbf{u}, \mathbf{v} \in C$,

$$f(\mathbf{v}) \geq f(\mathbf{u}) + \langle \nabla f(\mathbf{u}), \mathbf{v} - \mathbf{u} \rangle. \quad (3.4)$$

若 f 二阶可微，则这又等价于 $\nabla^2 f(\mathbf{w}) \geq \mathbf{0}$ 对所有 $\mathbf{w} \in C$ 成立。

证明. 若 f 凸, 令 $\phi(t) = f(\mathbf{u} + t(\mathbf{v} - \mathbf{u}))$ 。由凸性, $[\phi(t) - \phi(0)]/t \leq \phi(1) - \phi(0)$ 。令 $t \downarrow 0$ 便得式 (3.4)。反过来, 令 $\mathbf{z} = \theta \mathbf{u} + (1 - \theta) \mathbf{v}$, 分别把一阶不等式用于 $(\mathbf{z}, \mathbf{u})$ 和 $(\mathbf{z}, \mathbf{v})$, 乘以 θ 与 $1 - \theta$ 后相加, 线性项抵消, 得到式 (3.3)。

若 f 凸, 把一阶判据用于 $\mathbf{w}$ 与 $\mathbf{w} + t\mathbf{v}$, 再对 t 求二阶局部极限, 得到 $\mathbf{v}^\top \nabla^2 f(\mathbf{w}) \mathbf{v} \geq 0$ 。反之, 沿任意线段定义 $\phi(t)$, 则 $\phi''(t) = (\mathbf{v} - \mathbf{u})^\top \nabla^2 f(\mathbf{u} + t(\mathbf{v} - \mathbf{u}))(\mathbf{v} - \mathbf{u}) \geq 0$, 一元函数 ϕ 凸, 故 f 凸。 ■

¹ S. Boyd, L. Vandenberghe, *Convex Optimization*, Cambridge University Press, 2004

反复应用二点凸性可得**Jensen 不等式** (Jensen's inequality)。若 $\alpha_i \geq 0$ 且 $\sum_i \alpha_i = 1$, 则

$$f\left(\sum_{i=1}^m \alpha_i \mathbf{w}_i\right) \leq \sum_{i=1}^m \alpha_i f(\mathbf{w}_i). \quad (3.5)$$

归纳步骤把前 $m-1$ 个点先归一化为一个加权平均, 再与第 m 个点应用二点凸性。这个证明也说明非负和归一化不是装饰条件; 允许负权重后, 组合点可能落到凸包之外, 因而不能再由凸性保证 Jensen 不等式。

凸性还把最优性变成可核验的一阶条件。若 f 可微且凸, 则 $\nabla f(\mathbf{w}^*) = \mathbf{0}$ 代入式 (3.4) 使得 $f(\mathbf{v}) \geq f(\mathbf{w}^*)$ 。因此凸问题的驻点是全局最小点。

严格凸要求非平凡线段上的式 (3.3) 严格成立, 它保证至多一个最小点, 却不给统一曲率下界。 μ **强凸** (μ -strongly convex) 要求

$$f(\mathbf{v}) \geq f(\mathbf{u}) + \langle \nabla f(\mathbf{u}), \mathbf{v} - \mathbf{u} \rangle + \frac{\mu}{2} \|\mathbf{v} - \mathbf{u}\|_2^2.$$

L **光滑** (L -smooth) 则要求梯度满足 $\|\nabla f(\mathbf{u}) - \nabla f(\mathbf{v})\|_2 \leq L \|\mathbf{u} - \mathbf{v}\|_2$ 。强凸给下曲率, 光滑给上曲率; x^4 严格凸但不在全实线上强凸, 也不在全实线上具有有限的光滑常数。

3.2.2 最近点、分离与支撑

定理 3.2 闭凸集外一点的严格分离 设 $C \subseteq \mathbb{R}^d$ 非空、闭且凸, $\mathbf{z} \notin C$ 。则存在 $\mathbf{a} \neq \mathbf{0}$ 和 $c \in \mathbb{R}$, 使

$$\langle \mathbf{a}, \mathbf{x} \rangle \leq c < \langle \mathbf{a}, \mathbf{z} \rangle \quad \text{对所有 } \mathbf{x} \in C.$$

证明. 先证明所需最近点的存在性与唯一性。任取 $\mathbf{x}_0 \in C$ 并令 $R = \|\mathbf{z} - \mathbf{x}_0\|_2$ 。集合

$$C_R = C \cap \{\mathbf{x} : \|\mathbf{z} - \mathbf{x}\|_2 \leq R\}$$

非空、闭且有界, 因而在有限维空间中紧。连续函数 $\|\mathbf{z} - \mathbf{x}\|_2^2$ 在 C_R 上达到最小值; 球外各点到 $\mathbf{z}$ 的距离大于 R , 而 $\mathbf{x}_0$ 的距离等于 R , 所以该最小点也是 C 上的最近点。若 $\mathbf{p}_1, \mathbf{p}_2$ 都是最近点, 最近距离为 δ , 则凸性保证其中点属于 C , 且

$$\left\| \mathbf{z} - \frac{\mathbf{p}_1 + \mathbf{p}_2}{2} \right\|_2^2 = \frac{1}{2} \|\mathbf{z} - \mathbf{p}_1\|_2^2 + \frac{1}{2} \|\mathbf{z} - \mathbf{p}_2\|_2^2 - \frac{1}{4} \|\mathbf{p}_1 - \mathbf{p}_2\|_2^2.$$

当 $\mathbf{p}_1 \neq \mathbf{p}_2$ 时, 右端严格小于 δ^2 , 与最近距离的定义矛盾, 故最近点唯一, 记为 $\mathbf{p}$ 。

对任意 $\mathbf{x} \in C$, $\mathbf{p} + t(\mathbf{x} - \mathbf{p}) \in C$ 。函数 $q(t) = \|\mathbf{z} - \mathbf{p} - t(\mathbf{x} - \mathbf{p})\|_2^2$ 在 $t = 0$ 处右导数非负, 所以 $\langle \mathbf{z} - \mathbf{p}, \mathbf{x} - \mathbf{p} \rangle \leq 0$ 。取 $\mathbf{a} = \mathbf{z} - \mathbf{p}$ 和 $c = \langle \mathbf{a}, \mathbf{p} \rangle$,

则 $\langle \mathbf{a}, \mathbf{x} \rangle \leq c$, 而 $\langle \mathbf{a}, \mathbf{z} \rangle = c + \|\mathbf{a}\|_2^2 > c$. ■

等号对应的超平面若接触凸集, 称为**支撑超平面** (supporting hyperplane)。具体地说, 若 $\mathbf{p}$ 位于闭凸集 C 的边界, 可取一系列集外点 $\mathbf{z}^{(k)} \rightarrow \mathbf{p}$, 对每个点应用严格分离并把法向量归一化。单位球的紧性给出收敛子列, 极限法向量 $\mathbf{a} \neq \mathbf{0}$ 满足 $\langle \mathbf{a}, \mathbf{x} \rangle \leq \langle \mathbf{a}, \mathbf{p} \rangle$ 对所有 $\mathbf{x} \in C$ 成立。这说明边界处至少有一个支撑方向, 但边界有棱角时法向量未必唯一。分离把“点不属于集合”转化为一个线性不等式证书, 但它本身不自动给出一般凸问题的强对偶; 还需要闭性或约束资格条件。

对称矩阵集合中的**半正定锥** (positive semidefinite cone)

$$\mathbb{S}_+^d = \{\mathbf{M} = \mathbf{M}^\top : \mathbf{v}^\top \mathbf{M} \mathbf{v} \geq 0, \forall \mathbf{v}\}$$

是凸锥, 因为非负线性组合仍保持二次型非负。它也是闭集: 若 $\mathbf{M}^{(k)} \rightarrow \mathbf{M}$ 且每个 $\mathbf{M}^{(k)} \geq \mathbf{0}$, 则对任意固定 $\mathbf{v}$ 都有 $\mathbf{v}^\top \mathbf{M} \mathbf{v} = \lim_k \mathbf{v}^\top \mathbf{M}^{(k)} \mathbf{v} \geq 0$ 。线性规划的非负正交锥和半正定规划的矩阵约束直接定义凸可行域; 标准凸二次规划中的半正定曲率矩阵则保证目标凸。三者共享的是凸目标与凸可行域的语言。若要进一步统一成带线性目标的锥规划, 还需引入辅助变量, 对二次目标作上图或锥提升。

3.3 较弱曲率与非凸结构

3.3.1 弱凸与补足曲率

强凸同时控制函数形状和误差。实际目标可能不凸, 却仍有足够结构支持算法分析。 ρ **弱凸** (ρ -weakly convex) 表示 $f(\mathbf{w}) + \rho\|\mathbf{w}\|_2^2/2$ 是凸函数。若 f 二阶可微, 这等价于 $\nabla^2 f(\mathbf{w}) \geq -\rho \mathbf{I}$: 负曲率可以存在, 但有统一下界。当 $\rho > 0$ 且 $0 < \eta < 1/\rho$ 时, 对任意中心 $\mathbf{z}$, 邻近子问题的目标

$$f(\mathbf{w}) + \frac{1}{2\eta} \|\mathbf{w} - \mathbf{z}\|_2^2$$

是 $(1/\eta - \rho)$ 强凸函数; 若 $\rho = 0$, 任意 $\eta > 0$ 都具有同样的补足曲率作用。这正是弱凸性与第 3.9 节邻近方法的联系。补入二次曲率只让这个子问题更易控制, 并没有把原函数变成凸函数; 弱凸目标仍可有局部极小点和鞍点, 也不保证求得原问题的全局最优解。

3.3.2 梯度控制目标误差的 PL 条件

Polyak-Łojasiewicz 条件 (PL condition) 不约束函数图像必须凸, 而要求

$$\frac{1}{2} \|\nabla f(\mathbf{w})\|_2^2 \geq \mu(f(\mathbf{w}) - f^*), \quad \mu > 0. \quad (3.6)$$

它直接把小梯度与小目标误差联系起来。强凸可推出 PL 条件：对 μ 强凸可微函数，把强凸下界右侧关于 $\mathbf{w}$ 最小化，得到

$$f^* \geq f(\mathbf{w}) - \frac{1}{2\mu} \|\nabla f(\mathbf{w})\|_2^2,$$

移项正是式 (3.6)。这个推导使用全局强凸下界；只有局部 Hessian 正定时，不能直接得到全域 PL 条件。反过来，PL 函数可以有多个最小点。

同一个低维族能显示这些性质各自控制什么。令

$$f_a(x_1, x_2) = \frac{1}{2}(x_1 + x_2)^2 + \frac{a}{2}(x_1 - x_2)^2.$$

当 $a > 0$ 时函数强凸； $a = 0$ 时它凸且满足 PL 条件，但整条直线 $x_1 + x_2 = 0$ 都是最小点； $a < 0$ 时函数弱凸却无下界。若限制在紧可行域上， $a < 0$ 时仍有最小点，但驻点 $(0, 0)$ 可能是鞍点。这个例子说明弱凸、PL 和强凸不是一条简单的强弱链：弱凸限制最坏负曲率，PL 控制梯度与目标误差，强凸还控制参数距离与唯一性。

PL 条件也确实可以出现在非凸函数中。考虑

$$f(x, y) = x^2 + 2 \sin^2 x.$$

它与 y 无关，因而最小点不唯一。其一阶导数为 $\partial f / \partial x = 2(x + \sin 2x)$ ；当 $x > 0$ 时，若 $x \leq 1$ 则两项均非负，若 $x > 1$ 则 $x + \sin 2x \geq x - 1 > 0$ ，负半轴由奇对称性处理，所以导数只在 $x = 0$ 时为零。比值

$$R(x) = \frac{\|\nabla f(x, y)\|_2^2}{2f(x, y)}$$

在 $x \neq 0$ 时为正，并且 $x \rightarrow 0$ 时趋于 6， $|x| \rightarrow \infty$ 时趋于 2。把两端之外的剩余区域限制为紧集，连续函数 R 在其中有正下界，故某个 $\mu > 0$ 使式 (3.6) 成立。另一方面， $\partial^2 f / \partial x^2 = 2 + 4 \cos 2x$ 在某些点为负，所以 f 并不凸；该二阶导数下界为 -2 、绝对值上界为 6，又说明它同时是 2 弱凸且 6 光滑。这个例子不能推出所有弱凸函数都满足 PL 条件，它只表明非凸性本身不排斥目标值的梯度控制。

式 (3.1) 的 Hessian 矩阵为 $\mathbf{X}^\top \mathbf{X} / n + \lambda \mathbf{I}$ 。当 $\lambda > 0$ 时，正则项把所有缺失曲率的方向至少抬高到 λ ，因而目标 λ 强凸。若 $\lambda = 0$ 且 $\mathbf{X}$ 不满列秩，驻点仍是全局最优点，但解不唯一；若目标再加入非凸项，驻点甚至不再保证局部最小。

3.4 梯度下降与步长

3.4.1 光滑上界与单步下降

梯度给出最陡的一阶下降方向，但一步走多远取决于函数弯曲程度。光滑性把局部线性近似的余项控制为二次量²。

² J. Nocedal, S. J. Wright, *Numerical Optimization*, Springer, 2006, 2nd ed.

引理 3.3 下降引理 若 f 的梯度是 L -Lipschitz 连续的，则

$$f(\mathbf{v}) \leq f(\mathbf{u}) + \langle \nabla f(\mathbf{u}), \mathbf{v} - \mathbf{u} \rangle + \frac{L}{2} \|\mathbf{v} - \mathbf{u}\|_2^2. \quad (3.7)$$

证明. 令 $\mathbf{d} = \mathbf{v} - \mathbf{u}$ 。沿线段积分并减去一阶项可得

$$f(\mathbf{v}) - f(\mathbf{u}) - \langle \nabla f(\mathbf{u}), \mathbf{d} \rangle = \int_0^1 \langle \nabla f(\mathbf{u} + t\mathbf{d}) - \nabla f(\mathbf{u}), \mathbf{d} \rangle dt.$$

由 Cauchy-Schwarz 不等式和梯度 Lipschitz 条件，被积函数至多为 $Lt\|\mathbf{d}\|_2^2$ ；积分即得结论。 ■

梯度下降按

$$\mathbf{w}^{(t+1)} = \mathbf{w}^{(t)} - \eta \nabla f(\mathbf{w}^{(t)}) \quad (3.8)$$

更新。把 $\mathbf{v}$ 取为右端点代入下降引理，得到

$$f(\mathbf{w}^{(t+1)}) \leq f(\mathbf{w}^{(t)}) - \eta \left(1 - \frac{L\eta}{2}\right) \|\nabla f(\mathbf{w}^{(t)})\|_2^2. \quad (3.9)$$

所以 $0 < \eta < 2/L$ 保证每个非驻点处严格下降。若 f 下有界，记其有限下确界为

$$f_{\inf} := \inf_{\mathbf{w} \in \mathbb{R}^d} f(\mathbf{w}) > -\infty.$$

取 $\eta = 1/L$ 并对 $t = 0, \dots, T-1$ 求和，可得非凸光滑情形的保证

$$\min_{0 \leq t < T} \|\nabla f(\mathbf{w}^{(t)})\|_2^2 \leq \frac{2L(f(\mathbf{w}^{(0)}) - f_{\inf})}{T}. \quad (3.10)$$

它只说明某次迭代接近驻点，没有声称驻点是全局最优点。

步长上界在一维二次函数上即可看到。对 $f(w) = Lw^2/2$ ， $w^{(t+1)} = (1 - \eta L)w^{(t)}$ 。当 $\eta = 2/L$ 时迭代在正负之间等幅振荡； $\eta > 2/L$ 时幅度按 $|1 - \eta L| > 1$ 增长。负梯度方向本身没有错，失败来自步长跨过了曲率允许的稳定性范围。

3.4.2 不同曲率下的收敛证明

若 f 还凸、最小点 $\mathbf{w}^*$ 存在, 并继续取 $\eta = 1/L$, 则由凸性有 $f(\mathbf{w}^{(t)}) - f^* \leq \langle \nabla f(\mathbf{w}^{(t)}), \mathbf{w}^{(t)} - \mathbf{w}^* \rangle$ 。先展开距离平方并使用这个不等式:

$$\begin{aligned} \|\mathbf{w}^{(t+1)} - \mathbf{w}^*\|_2^2 &= \|\mathbf{w}^{(t)} - \mathbf{w}^*\|_2^2 - \frac{2}{L} \langle \nabla f(\mathbf{w}^{(t)}), \mathbf{w}^{(t)} - \mathbf{w}^* \rangle \\ &\quad + \frac{1}{L^2} \|\nabla f(\mathbf{w}^{(t)})\|_2^2 \\ &\leq \|\mathbf{w}^{(t)} - \mathbf{w}^*\|_2^2 - \frac{2}{L} (f(\mathbf{w}^{(t)}) - f^*) \\ &\quad + \frac{1}{L^2} \|\nabla f(\mathbf{w}^{(t)})\|_2^2. \end{aligned}$$

另一方面, 把 $\eta = 1/L$ 代入式 (3.9) 可得

$$\frac{1}{L^2} \|\nabla f(\mathbf{w}^{(t)})\|_2^2 \leq \frac{2}{L} (f(\mathbf{w}^{(t)}) - f(\mathbf{w}^{(t+1)})).$$

用后一式消去梯度平方项, 得到

$$\|\mathbf{w}^{(t+1)} - \mathbf{w}^*\|_2^2 \leq \|\mathbf{w}^{(t)} - \mathbf{w}^*\|_2^2 - \frac{2}{L} (f(\mathbf{w}^{(t+1)}) - f^*).$$

对 $t = 0, \dots, T-1$ 求和并去掉末端的非负距离, 便有

$$\frac{2}{L} \sum_{t=0}^{T-1} (f(\mathbf{w}^{(t+1)}) - f^*) \leq \|\mathbf{w}^{(0)} - \mathbf{w}^*\|_2^2.$$

式 (3.9) 还说明目标值单调不增, 因此左侧求和中的每一项都不小于 $f(\mathbf{w}^{(T)}) - f^*$ 。于是

$$f(\mathbf{w}^{(T)}) - f^* \leq \frac{L \|\mathbf{w}^{(0)} - \mathbf{w}^*\|_2^2}{2T}. \quad (3.11)$$

若满足 PL 条件, 把式 (3.6) 代入式 (3.9), 在 $\eta = 1/L$ 时得到

$$f(\mathbf{w}^{(t)}) - f^* \leq \left(1 - \frac{\mu}{L}\right)^t (f(\mathbf{w}^{(0)}) - f^*). \quad (3.12)$$

强凸函数满足 PL 条件, 还由 $f(\mathbf{w}) - f^* \geq \mu \|\mathbf{w} - \mathbf{w}^*\|_2^2 / 2$ 把目标误差转成参数误差。没有强凸时, 式 (3.12) 不保证迭代趋向某个唯一参数。

固定步长需要已知或估计 L 。回溯线搜索从候选步长开始缩小, 直到 $f(\mathbf{w} - \eta \nabla f(\mathbf{w})) \leq f(\mathbf{w}) - c\eta \|\nabla f(\mathbf{w})\|_2^2$ 成立, 其中 $c \in (0, 1)$ 。学习率调度则预先或按进度改变 η_t 。线搜索用实际函数值核验当前一步, 调度只规定时间表; 二者都不能弥补错误梯度或无下界目标。

3.5 曲率、加速与预条件

3.5.1 动量与加速的递推结构

对二次函数 $f(\mathbf{w}) = \frac{1}{2} \mathbf{w}^\top \mathbf{H} \mathbf{w} - \mathbf{c}^\top \mathbf{w}$, 梯度下降的误差满足 $\mathbf{e}^{(t+1)} = (\mathbf{I} - \eta \mathbf{H}) \mathbf{e}^{(t)}$ 。当 $\mathbf{H} > \mathbf{0}$ 但条件数 $\kappa = L/\mu$ 很大时, 同一步长必须同时照顾陡峭与平坦方向, 平坦方向因而收敛缓慢。

动量法 (momentum method) 保存过去方向:

$$\mathbf{v}^{(t+1)} = \beta \mathbf{v}^{(t)} + \nabla f(\mathbf{w}^{(t)}), \quad \mathbf{w}^{(t+1)} = \mathbf{w}^{(t)} - \eta \mathbf{v}^{(t+1)}.$$

它通过二阶递推重塑各特征方向上的多项式响应, 但 β 和 η 不能各自独立地任取。对上述正定二次目标, 曲率为 λ_i 的特征方向满足

$$e_i^{(t+1)} = (1 + \beta - \eta \lambda_i) e_i^{(t)} - \beta e_i^{(t-1)}.$$

该方向的两个特征根都严格位于单位圆内, 当且仅当 $-1 < \beta < 1$ 且 $0 < \eta \lambda_i < 2(1 + \beta)$ 。因而常用的 $0 \leq \beta < 1$ 还须配合 $0 < \eta < 2(1 + \beta)/L$, 才能保证所有方向稳定。若已知 $0 < \mu \leq \lambda_i \leq L$, 经典重球参数

$$\eta = \frac{4}{(\sqrt{L} + \sqrt{\mu})^2}, \quad \beta = \left(\frac{\sqrt{L} - \sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}} \right)^2$$

给出这一二次模型上的代表性最坏方向速率; 它不是一般非凸目标或含噪梯度下的无条件调参规则。

Nesterov 加速梯度 (Nesterov accelerated gradient) 在前瞻点计算梯度:

$$\mathbf{z}^{(t)} = \mathbf{w}^{(t)} + \beta_t (\mathbf{w}^{(t)} - \mathbf{w}^{(t-1)}), \quad \mathbf{w}^{(t+1)} = \mathbf{z}^{(t)} - \frac{1}{L} \nabla f(\mathbf{z}^{(t)}).$$

令 $\mathbf{w}^{(-1)} = \mathbf{w}^{(0)}$ 、 $q_0 = 1$, 并取

$$q_{t+1} = \frac{1 + \sqrt{1 + 4q_t^2}}{2}, \quad \beta_t = \frac{q_t - 1}{q_{t+1}}.$$

若 f 为凸可微函数、梯度 L -Lipschitz 连续、最小点存在, 并且每步使用精确梯度和步长 $1/L$, 则上述选择给出 $f(\mathbf{w}^{(t)}) - f^* = O(1/t^2)$; 同样条件下, 普通梯度下降的一般保证为 $O(1/t)$ 。强凸时还可采用依赖 μ/L 的固定系数得到线性速率, 但那是另一组参数和证明。在一维二次函数 $f(w) = \lambda w^2/2$ 上, 这个迭代可直接核验为

$$w^{(t+1)} = \left(1 - \frac{\lambda}{L}\right) ((1 + \beta_t) w^{(t)} - \beta_t w^{(t-1)}).$$

当 $\lambda = L$ 时一步到达零点; 当 $\lambda \ll L$ 时, 跨步项改变平坦方向上的二阶递推, 但系数选错仍会振荡。一般凸证明不能只检查这个二次算例, 而是构造同时含目标误差与外推距离的势函数; $q_{t+1}^2 - q_{t+1} = q_t^2$ 使相邻两步的耦

合项抵消，最终留下 $q_t^2(f(\mathbf{w}^{(t)}) - f^*)$ 的统一上界。加速结论因此来自特定外推序列与势函数不等式，不能由“加入惯性”本身推出。

3.5.2 牛顿、近似曲率与正定预条件

牛顿法 (Newton's method) 在 $\mathbf{w}^{(t)}$ 处使用关于增量 $\mathbf{p}$ 的局部二次模型

$$m_t(\mathbf{p}) = f(\mathbf{w}^{(t)}) + \langle \nabla f(\mathbf{w}^{(t)}), \mathbf{p} \rangle + \frac{1}{2} \mathbf{p}^\top \nabla^2 f(\mathbf{w}^{(t)}) \mathbf{p}.$$

令 $\nabla_{\mathbf{p}} m_t(\mathbf{p}^{(t)}) = \mathbf{0}$ ，便得到牛顿方程

$$\nabla^2 f(\mathbf{w}^{(t)}) \mathbf{p}^{(t)} = -\nabla f(\mathbf{w}^{(t)}), \quad \mathbf{w}^{(t+1)} = \mathbf{w}^{(t)} + \alpha_t \mathbf{p}^{(t)}.$$

若 Hessian 矩阵在最优点附近正定且 Lipschitz 连续，取单位步长可得到局部二次收敛。但 Hessian 矩阵不定时，牛顿方向未必下降；离最优点较远时还需线搜索或信赖域。

对非线性最小二乘 $f(\mathbf{w}) = \frac{1}{2} \|\mathbf{r}(\mathbf{w})\|_2^2$ ，设 $\mathbf{r} : \mathbb{R}^d \rightarrow \mathbb{R}^m$ 。记残差向量的 Jacobian 矩阵为 $\mathbf{J}(\mathbf{w}) \in \mathbb{R}^{m \times d}$ ，其第 i 行为 $\mathbf{J}_{i,:}(\mathbf{w}) = \nabla r_i(\mathbf{w})^\top$ ，则

$$\nabla^2 f(\mathbf{w}) = \mathbf{J}(\mathbf{w})^\top \mathbf{J}(\mathbf{w}) + \sum_{i=1}^m r_i(\mathbf{w}) \nabla^2 r_i(\mathbf{w}).$$

Gauss-Newton 法 忽略第二项，使用半正定矩阵 $\mathbf{J}^\top \mathbf{J}$ 。当残差小或残差函数近似线性时近似合理；残差大时，省略项可能决定曲率。

拟牛顿法 (quasi-Newton method) 不显式计算 Hessian 矩阵，而用梯度差 $\mathbf{y}^{(t)} = \nabla f(\mathbf{w}^{(t+1)}) - \nabla f(\mathbf{w}^{(t)})$ 和步长 $\mathbf{s}^{(t)} = \mathbf{w}^{(t+1)} - \mathbf{w}^{(t)}$ 更新矩阵近似，并满足割线条件 $\mathbf{B}^{(t+1)} \mathbf{s}^{(t)} = \mathbf{y}^{(t)}$ 。若 $\mathbf{B}^{(t)}$ 近似 Hessian 矩阵，BFGS 更新为

$$\mathbf{B}^{(t+1)} = \mathbf{B}^{(t)} + \frac{\mathbf{y}^{(t)}(\mathbf{y}^{(t)})^\top}{(\mathbf{y}^{(t)})^\top \mathbf{s}^{(t)}} - \frac{\mathbf{B}^{(t)} \mathbf{s}^{(t)}(\mathbf{s}^{(t)})^\top \mathbf{B}^{(t)}}{(\mathbf{s}^{(t)})^\top \mathbf{B}^{(t)} \mathbf{s}^{(t)}}. \quad (3.13)$$

当 $\mathbf{B}^{(t)} > \mathbf{0}$ 且曲率条件 $(\mathbf{y}^{(t)})^\top \mathbf{s}^{(t)} > 0$ 成立时，式 (3.13) 保持 $\mathbf{B}^{(t+1)} > \mathbf{0}$ ，相应搜索方向 $-(\mathbf{B}^{(t+1)})^{-1} \nabla f$ 才由正定性保证是下降方向。沿下降方向执行满足 Wolfe 条件的线搜索可产生该正曲率内积。具体地，令 $\mathbf{w}^{(t+1)} = \mathbf{w}^{(t)} + \alpha_t \mathbf{p}^{(t)}$ ，其中 $\nabla f(\mathbf{w}^{(t)})^\top \mathbf{p}^{(t)} < 0$ 。Wolfe 条件要求存在 $0 < c_1 < c_2 < 1$ 使

$$\begin{aligned} f(\mathbf{w}^{(t+1)}) &\leq f(\mathbf{w}^{(t)}) + c_1 \alpha_t \nabla f(\mathbf{w}^{(t)})^\top \mathbf{p}^{(t)}, \\ \nabla f(\mathbf{w}^{(t+1)})^\top \mathbf{p}^{(t)} &\geq c_2 \nabla f(\mathbf{w}^{(t)})^\top \mathbf{p}^{(t)}. \end{aligned} \quad (3.14)$$

第二行就是 **Wolfe 曲率条件** (Wolfe curvature condition)。由 $\mathbf{s}^{(t)} = \alpha_t \mathbf{p}^{(t)}$ 可得

$$(\mathbf{y}^{(t)})^\top \mathbf{s}^{(t)} \geq \alpha_t (c_2 - 1) \nabla f(\mathbf{w}^{(t)})^\top \mathbf{p}^{(t)} > 0.$$

非凸或梯度含噪时，上述条件可能难以满足，此时可能需要阻尼或跳过更新。

预条件 (preconditioning) 则选择正定矩阵 $\mathbf{P}$ ，按

$$\mathbf{w}^{(t+1)} = \mathbf{w}^{(t)} - \eta \mathbf{P} \nabla f(\mathbf{w}^{(t)})$$

更新。这等价于在新的坐标或内积下做最陡下降。若 $p_i > 0$ ，并且

$$\mathbf{P} = \mathbf{Q} \text{diag}(p_1, \dots, p_d) \mathbf{Q}^\top,$$

则定义

$$\mathbf{P}^{1/2} = \mathbf{Q} \text{diag}(\sqrt{p_1}, \dots, \sqrt{p_d}) \mathbf{Q}^\top.$$

这就是 $\mathbf{P}$ 唯一的对称正定平方根：它满足 $\mathbf{P}^{1/2} \mathbf{P}^{1/2} = \mathbf{P}$ ，并且可逆，其逆记为 $\mathbf{P}^{-1/2}$ 。对当前正定二次目标，记

$$\tilde{\mathbf{H}} = \mathbf{P}^{1/2} \mathbf{H} \mathbf{P}^{1/2}, \quad 0 < \tilde{\mu} = \lambda_{\min}(\tilde{\mathbf{H}}) \leq \lambda_{\max}(\tilde{\mathbf{H}}) = \tilde{L}.$$

原坐标中的误差递推为 $\mathbf{e}^{(t+1)} = (\mathbf{I} - \eta \mathbf{P} \mathbf{H}) \mathbf{e}^{(t)}$ 。令 $\tilde{\mathbf{e}}^{(t)} = \mathbf{P}^{-1/2} \mathbf{e}^{(t)}$ ，则

$$\tilde{\mathbf{e}}^{(t+1)} = (\mathbf{I} - \eta \tilde{\mathbf{H}}) \tilde{\mathbf{e}}^{(t)}, \quad \mathbf{P}^{-1/2} (\mathbf{I} - \eta \mathbf{P} \mathbf{H}) \mathbf{P}^{1/2} = \mathbf{I} - \eta \tilde{\mathbf{H}}.$$

右侧矩阵由可逆坐标变换 $\mathbf{P}^{1/2}$ 得到，因而与原误差递推矩阵相似；相似矩阵具有相同特征值。由于 $\tilde{\mathbf{H}}$ 对称正定，迭代对任意初始误差收敛当且仅当 $0 < \eta < 2/\tilde{L}$ 。取 $\eta = 2/(\tilde{L} + \tilde{\mu})$ 时，在变换后的欧氏范数中，每步最坏收缩因子为

$$\frac{\tilde{\kappa} - 1}{\tilde{\kappa} + 1}, \quad \tilde{\kappa} = \frac{\tilde{L}}{\tilde{\mu}}.$$

因此预条件的目标不是单独让 $\mathbf{P}$ 的条件数小，而是让变换后曲率 $\tilde{\mathbf{H}}$ 的条件数接近 1。固定 $\mathbf{P} > \mathbf{0}$ 只保证定义了合法内积；若它与 $\mathbf{H}$ 不匹配， $\tilde{\kappa}$ 反而可能增大。对一般二阶可微的光滑强凸函数，需要在所有迭代经过的区域统一满足 $\tilde{\mu} \mathbf{I} \leq \mathbf{P}^{1/2} \nabla^2 f(\mathbf{w}) \mathbf{P}^{1/2} \leq \tilde{L} \mathbf{I}$ ，上述步长范围与线性收敛解释才相应延续；变化的预条件矩阵还需额外控制。

动量利用历史更新，牛顿类近似当前曲率，预条件改变几何尺度；三者可能组合，却不是同一种机制。第 6 章将在矩阵函数与 Kronecker 结构建立后给出结构化预条件，Fisher 矩阵与经验梯度二阶矩的差别则需等概率对象建立后讨论。

3.6 约束与拉格朗日乘子

3.6.1 可行方向与 KKT 条件

资源约束使最优点处的目标梯度不必为零，因为可行方向受到限制。对

$$\min_{\mathbf{w}} f(\mathbf{w}) \quad \text{s.t.} \quad a_j(\mathbf{w}) = 0 \ (j = 1, \dots, m), \quad g_k(\mathbf{w}) \leq 0 \ (k = 1, \dots, p),$$

在可行点 $\mathbf{w}$ 处，满足

$$\langle \nabla a_j(\mathbf{w}), \mathbf{d} \rangle = 0, \quad \langle \nabla g_k(\mathbf{w}), \mathbf{d} \rangle \leq 0 \quad \text{对所有活跃的 } g_k$$

的方向 $\mathbf{d}$ 称为**一阶可行方向** (linearized feasible direction)。等式约束为何产生法向量平衡，可以先看仿射情形 $\mathbf{A}\mathbf{w} = \mathbf{b}$ 。任一可行扰动都满足 $\mathbf{A}\mathbf{d} = \mathbf{0}$ ；局部最优点不能沿 $\mathbf{d}$ 或 $-\mathbf{d}$ 下降，故 $\langle \nabla f(\mathbf{w}^*), \mathbf{d} \rangle = 0$ 对所有 $\mathbf{d} \in \ker \mathbf{A}$ 成立。由 $(\ker \mathbf{A})^\perp = \text{range}(\mathbf{A}^\top)$ ，存在不受符号限制的 $\boldsymbol{\nu}$ 使 $\nabla f(\mathbf{w}^*) = -\mathbf{A}^\top \boldsymbol{\nu}$ 。

活跃不等式只允许切平面一侧的一阶移动，它的外法向量因而以非负系数参与梯度平衡；不活跃约束在该点留有严格余量，不限制足够小的移动，对应系数应为零。这分别引出非负乘子与互补松弛。在适当的约束资格条件下，这些几何关系可通过**拉格朗日函数** (Lagrangian) 统一表达：

$$\mathcal{L}(\mathbf{w}, \boldsymbol{\nu}, \boldsymbol{\alpha}) = f(\mathbf{w}) + \sum_j \nu_j a_j(\mathbf{w}) + \sum_k \alpha_k g_k(\mathbf{w}), \quad \boldsymbol{\nu} \in \mathbb{R}^m, \quad \boldsymbol{\alpha} \in \mathbb{R}_+^p.$$

乘子把违反约束的边际代价并入目标。

Karush-Kuhn-Tucker 条件 (KKT conditions) 包括

$$\nabla_{\mathbf{w}} \mathcal{L}(\mathbf{w}^*, \boldsymbol{\nu}^*, \boldsymbol{\alpha}^*) = \mathbf{0}, \quad \text{驻点性,} \quad (3.15)$$

$$a_j(\mathbf{w}^*) = 0, \quad g_k(\mathbf{w}^*) \leq 0, \quad \text{原始可行性,} \quad (3.16)$$

$$\alpha_k^* \geq 0, \quad \text{对偶可行性,} \quad (3.17)$$

$$\alpha_k^* g_k(\mathbf{w}^*) = 0, \quad \text{互补松弛.} \quad (3.18)$$

互补松弛表示未用尽的约束不能有正价格，正价格只可能出现在活跃边界上。

局部最优点满足 KKT 条件需要**约束资格条件** (constraint qualification)。例如活跃不等式梯度与等式梯度线性无关时，沿可行方向的一阶下降不可能存在，由有限维分离可得到乘子。没有资格条件，乘子可能不存在。例 $f(x) = x$ 且约束 $x^2 \leq 0$ 只有可行点 $x = 0$ ，它当然最优；但约束梯度为零，驻点条件 $1 + \alpha \cdot 0 = 0$ 无解。

反方向在凸情形更强。若 f 和每个 g_k 均为可微凸函数， a_j 仿射，且某个可行点与乘子满足 KKT，则对任意可行 $\mathbf{w}$ ，仿射等式约束使 $\langle \nabla a_j(\mathbf{w}^*), \mathbf{w} - \mathbf{w}^* \rangle = 0$ 。

$\mathbf{w}^* \rangle = a_j(\mathbf{w}) - a_j(\mathbf{w}^*) = 0$ 。因此等式乘子项消失，再由凸性和驻点性，

$$f(\mathbf{w}) \geq f(\mathbf{w}^*) - \sum_k \alpha_k^* \langle \nabla g_k(\mathbf{w}^*), \mathbf{w} - \mathbf{w}^* \rangle \geq f(\mathbf{w}^*).$$

最后一步使用凸约束的一阶下界、可行性和互补松弛。因此 KKT 在该条件下足以保证全局最优。

3.6.2 活跃集与解的敏感性

示例 3.4 预算约束、活跃集与敏感性 求最接近 $\mathbf{c} = (2, 1)^\top$ 的非负分配，并令总预算为 $\tau > 0$ ：

$$\min_{\mathbf{w}} \frac{1}{2} \|\mathbf{w} - \mathbf{c}\|_2^2 \quad \text{s.t.} \quad w_1 + w_2 \leq \tau, \quad -w_1 \leq 0, \quad -w_2 \leq 0.$$

当 $\tau > 3$ 时， $\mathbf{c}$ 本身严格满足预算约束，故该约束不活跃，且 $\mathbf{w}^*(\tau) = (2, 1)^\top$ 。当 $\tau = 3$ 时解仍为 $\mathbf{c}$ ，预算约束活跃，但其乘子为零；这个边界说明“约束活跃”不等于“乘子严格为正”。当 $1 < \tau < 3$ 时，两个坐标仍为正而预算取等。把预算这一不等式的乘子记为 α_{bud} ，驻点条件给

$$w_1 - 2 + \alpha_{\text{bud}} = 0, \quad w_2 - 1 + \alpha_{\text{bud}} = 0, \quad w_1 + w_2 = \tau.$$

因此

$$\mathbf{w}^*(\tau) = \left(\frac{\tau+1}{2}, \frac{\tau-1}{2} \right)^\top, \quad \alpha_{\text{bud}}^*(\tau) = \frac{3-\tau}{2}.$$

当 $0 < \tau < 1$ 时，第二个非负约束也活跃，解变成 $\mathbf{w}^*(\tau) = (\tau, 0)^\top$ ，预算乘子为 $2 - \tau$ ，第二个非负约束的乘子为 $1 - \tau$ 。在 $\tau = 1$ 处，第二个非负约束活跃但乘子为零。上述区域及边界分别展示预算不生效、约束活跃但零乘子、仅预算产生正价格，以及预算与坐标边界同时产生正价格。目标严格凸，满足 KKT 的点都是唯一全局最优解。

这个算例也把两类敏感性分开。在 $1 < \tau < 3$ 时， $d\mathbf{w}^*/d\tau = (1/2, 1/2)^\top$ ；在 $0 < \tau < 1$ 时则为 $(1, 0)^\top$ 。 $\tau = 1$ 处活跃集切换，解连续但导数改变。最优值为

$$V(\tau) = \begin{cases} 0, & \tau \geq 3, \\ (3-\tau)^2/4, & 1 \leq \tau \leq 3, \\ ((2-\tau)^2 + 1)/2, & 0 < \tau \leq 1. \end{cases}$$

在每个活跃集固定的开区间内， $V'(\tau) = -\alpha_{\text{bud}}^*(\tau)$ ：放宽一单位预算带来的最优值下降率正是预算乘子的相反数。解导数是向量，乘子给出的是最优值导数，二者不能混用。

一般地, 设问题依赖参数 τ , 活跃集在邻域内不变, 把驻点条件、等式和活跃约束写成 $\Phi(\mathbf{w}, \mathbf{v}, \boldsymbol{\alpha}, \tau) = \mathbf{0}$ 。若对前三组变量的 Jacobian 矩阵可逆, 则第 2 章的隐式求导给出

$$\frac{d}{d\tau} \begin{bmatrix} \mathbf{w}^* \\ \mathbf{v}^* \\ \boldsymbol{\alpha}^* \end{bmatrix} = - \left(\frac{\partial \Phi}{\partial (\mathbf{w}, \mathbf{v}, \boldsymbol{\alpha})} \right)^{-1} \frac{\partial \Phi}{\partial \tau}.$$

这个 Jacobian 是完整 KKT 系统的导数, 原目标 Hessian 可逆并不足以保证它可逆。活跃集改变或该矩阵奇异时, 解映射可能不可微; 此时不能跨越切换点沿用同一个导数。

3.7 原问题与对偶问题

3.7.1 Lagrangian 下界与弱对偶

对固定乘子 $\boldsymbol{\alpha} \geq \mathbf{0}$, 任意可行 $\mathbf{w}$ 都满足 $\mathcal{L}(\mathbf{w}, \mathbf{v}, \boldsymbol{\alpha}) \leq f(\mathbf{w})$ 。因此 **对偶函数** (dual function)

$$q(\mathbf{v}, \boldsymbol{\alpha}) = \inf_{\mathbf{w}} \mathcal{L}(\mathbf{w}, \mathbf{v}, \boldsymbol{\alpha})$$

给出原问题最优值的下界。最大化这个下界得到对偶问题。由构造立即有 $d^* \leq p^*$, 称为**弱对偶** (weak duality); 差 $p^* - d^*$ 称为对偶间隙。对某组乘子取下确界得到 $-\infty$, 表示这组乘子没有给出有限下界; 对偶不可行则表示没有任何乘子满足对偶问题规定的可行条件。前者描述一个候选乘子的函数值, 后者描述整个候选集合, 二者不能混用。

3.7.2 Farkas 择一与线性规划强对偶

线性规划的强对偶可以从一个不可行证书推出。先建立所需的择一定理³。

引理 3.5 有限生成锥的闭性 给定 $\mathbf{a}_1, \dots, \mathbf{a}_r \in \mathbb{R}^m$, 集合

$$K = \left\{ \sum_{i=1}^r \alpha_i \mathbf{a}_i : \alpha_i \geq 0 \right\}$$

是闭凸锥。

证明. 凸性和锥性质由非负线性组合直接得到。为证明闭性, 先注意每个 $\mathbf{x} \in K$ 都能由一组线性无关的生成向量作非负组合。若某个表示使用的生成向量线性相关, 就存在非零系数 $\boldsymbol{\gamma}$ 使 $\sum_i \gamma_i \mathbf{a}_i = \mathbf{0}$; 必要时改变符号, 使至少一个 $\gamma_i > 0$ 。从原系数中减去 $t\boldsymbol{\gamma}$, 其中 $t = \min_{\gamma_i > 0} \alpha_i / \gamma_i$, 仍保持所

³ S. Boyd, L. Vandenberghe, *Convex Optimization*, Cambridge University Press, 2004

有系数非负, 并使至少一个系数变为零。重复此过程便得到线性无关的表示。

现取 $\mathbf{x}^{(k)} \in K$ 且 $\mathbf{x}^{(k)} \rightarrow \mathbf{x}$ 。线性无关的生成子集只有有限多个, 故可取子列, 使每个 $\mathbf{x}^{(k)}$ 都使用同一个子集 J 。以这些向量为列组成满列秩矩阵 $\mathbf{A}_J$, 相应非负系数满足

$$\boldsymbol{\alpha}^{(k)} = (\mathbf{A}_J^\top \mathbf{A}_J)^{-1} \mathbf{A}_J^\top \mathbf{x}^{(k)} \longrightarrow (\mathbf{A}_J^\top \mathbf{A}_J)^{-1} \mathbf{A}_J^\top \mathbf{x}.$$

极限系数仍逐项非负, 且 $\mathbf{x}$ 等于 $\mathbf{A}_J$ 乘该极限系数, 故 $\mathbf{x} \in K$ 。 ■

引理 3.6 有限维多面体的线性像 有限维多面体在线性映射下的像仍是多面体, 因而是闭集。

证明. 设多面体 $P = \{\mathbf{u} : \mathbf{B}\mathbf{u} \leq \mathbf{d}\}$, 线性映射为 $\mathbf{v} = \mathbf{T}\mathbf{u}$ 。其图像

$$\{(\mathbf{u}, \mathbf{v}) : \mathbf{B}\mathbf{u} \leq \mathbf{d}, \mathbf{v} = \mathbf{T}\mathbf{u}\}$$

是多面体, 而 $\mathbf{TP}$ 是该图像消去 $\mathbf{u}$ 后的坐标投影。对一个待消变量, Fourier-Motzkin 消元分别收集其系数为正、为负和为零的不等式; 每一对正、负系数不等式消去该变量, 零系数不等式原样保留。所得有限组非严格线性不等式恰好描述投影。逐个消去 $\mathbf{u}$ 的坐标, 便得到 $\mathbf{TP}$ 的有限线性不等式表示。多面体是有限个闭半空间的交, 因此闭。 ■

定理 3.7 Farkas 择一定理 给定 $\mathbf{M} \in \mathbb{R}^{m \times d}$ 和 $\mathbf{r} \in \mathbb{R}^m$, 下列两个系统恰有一个可行:

$$\mathbf{M}\mathbf{x} = \mathbf{r}, \quad \mathbf{x} \geq \mathbf{0}; \quad \mathbf{M}^\top \mathbf{z} \geq \mathbf{0}, \quad \mathbf{r}^\top \mathbf{z} < 0.$$

证明. 两者不能同时成立, 因为若都成立, 则 $0 > \mathbf{r}^\top \mathbf{z} = \mathbf{x}^\top \mathbf{M}^\top \mathbf{z} \geq 0$, 矛盾。若第一个系统不可行, $\mathbf{r}$ 不属于锥 $K = \{\mathbf{M}\mathbf{x} : \mathbf{x} \geq \mathbf{0}\}$ 。它由 $\mathbf{M}$ 的有限个列向量生成, 故由引理 3.5 可知 K 是闭凸锥。对 K 与 $\mathbf{r}$ 应用定理 3.2, 得到 $\mathbf{a}$ 和 c , 使 $\langle \mathbf{a}, \mathbf{k} \rangle \leq c < \langle \mathbf{a}, \mathbf{r} \rangle$ 。由于 $\mathbf{0} \in K$, 有 $c \geq 0$; 又因为 $t\mathbf{k} \in K$ 对所有 $t \geq 0$ 成立, 必有 $\langle \mathbf{a}, \mathbf{k} \rangle \leq 0$, 否则取充分大的 t 便会超过 c 。令 $\mathbf{z} = -\mathbf{a}$, 可得 $\langle \mathbf{z}, \mathbf{r} \rangle < 0$ 且 $\langle \mathbf{z}, \mathbf{k} \rangle \geq 0$ 对所有 $\mathbf{k} \in K$ 成立。特别地, 对 $\mathbf{M}$ 的每个列向量成立, 故 $\mathbf{M}^\top \mathbf{z} \geq \mathbf{0}$ 。第二个系统可行。 ■

定理 3.8 有限维线性规划强对偶 考虑标准型原问题与对偶问题

$$\min_{\mathbf{x} \geq \mathbf{0}} \mathbf{c}^\top \mathbf{x} \quad \text{s.t.} \quad \mathbf{A}\mathbf{x} = \mathbf{b}, \quad \max_{\mathbf{y}} \mathbf{b}^\top \mathbf{y} \quad \text{s.t.} \quad \mathbf{A}^\top \mathbf{y} \leq \mathbf{c}.$$

若原问题可行且有限下确界为 p^* , 则原问题与对偶问题都有最优解, 且两个最优值都等于 p^* 。

证明. 原始可行域 $P = \{\mathbf{x} : \mathbf{Ax} = \mathbf{b}, \mathbf{x} \geq \mathbf{0}\}$ 是非空多面体。由引理 3.6, 其目标值集合

$$W = \{\mathbf{c}^\top \mathbf{x} : \mathbf{x} \in P\}$$

是 $\mathbb{R}$ 中的非空多面体。集合 W 下有界, 且一维多面体包含自己的有限下端点, 故 $p^* = \inf W$ 属于 W 。因此存在原始可行点 $\mathbf{x}^*$ 满足 $\mathbf{c}^\top \mathbf{x}^* = p^*$, 原问题达到其最优值。

对任意 $\varepsilon > 0$, 系统

$$\mathbf{Ax} = \mathbf{b}, \quad \mathbf{c}^\top \mathbf{x} + s = p^* - \varepsilon, \quad \mathbf{x} \geq \mathbf{0}, s \geq 0$$

不可行, 否则会有目标值小于 p^* 的原始可行点。对增广矩阵应用定理 3.7, 存在 $(\mathbf{y}_\varepsilon, \gamma_\varepsilon)$ 满足

$$\mathbf{A}^\top \mathbf{y}_\varepsilon + \gamma_\varepsilon \mathbf{c} \geq \mathbf{0}, \quad \gamma_\varepsilon \geq 0, \quad \mathbf{b}^\top \mathbf{y}_\varepsilon + \gamma_\varepsilon (p^* - \varepsilon) < 0.$$

取任一原始可行 $\bar{\mathbf{x}}$ 并与第一式作内积可知 $\gamma_\varepsilon > 0$, 否则会与最后一式矛盾。令 $\hat{\mathbf{y}}_\varepsilon = -\mathbf{y}_\varepsilon / \gamma_\varepsilon$, 便有 $\mathbf{A}^\top \hat{\mathbf{y}}_\varepsilon \leq \mathbf{c}$ 且 $\mathbf{b}^\top \hat{\mathbf{y}}_\varepsilon > p^* - \varepsilon$ 。

记对偶可行多面体为 $D = \{\mathbf{y} : \mathbf{A}^\top \mathbf{y} \leq \mathbf{c}\}$ 。上面的构造说明 D 非空, 且其目标值集合

$$V = \{\mathbf{b}^\top \mathbf{y} : \mathbf{y} \in D\}$$

对每个 $\varepsilon > 0$ 都包含一个大于 $p^* - \varepsilon$ 的值。弱对偶说明 V 中的每个值都不超过 p^* , 所以 $\sup V = p^*$ 。由引理 3.6, V 是 $\mathbb{R}$ 中的多面体; 非空的一维多面体只能是闭区间、闭射线、单点或整条实线。由于 V 有有限上确界, 它必包含上端点 p^* 。因此存在 $\mathbf{y}^* \in D$ 使 $\mathbf{b}^\top \mathbf{y}^* = p^*$, 对偶最优解达到与原问题相同的最优值。 ■

示例 3.9 二维资源分配的原始与对偶证书 考虑

$$\max_{x_1, x_2 \geq 0} 3x_1 + 2x_2 \quad \text{s.t.} \quad 2x_1 + x_2 \leq 4, \quad x_1 + 2x_2 \leq 4.$$

为两类资源设置价格 $u_1, u_2 \geq 0$ 。由于原问题是最大化, 对可行点的资源余量按非负价格计价会给出目标上界:

$$\begin{aligned} \mathcal{L}(\mathbf{x}, \mathbf{u}) &= 3x_1 + 2x_2 + u_1(4 - 2x_1 - x_2) + u_2(4 - x_1 - 2x_2) \\ &= 4u_1 + 4u_2 + (3 - 2u_1 - u_2)x_1 + (2 - u_1 - 2u_2)x_2. \end{aligned}$$

要使 $\sup_{\mathbf{x} \geq 0} \mathcal{L}(\mathbf{x}, \mathbf{u})$ 有限, x_1, x_2 的系数必须非正, 因而 $2u_1 + u_2 \geq 3$ 且 $u_1 + 2u_2 \geq 2$ 。此时上确界就是 $4u_1 + 4u_2$, 最小化这个上界得到对偶

$$\min_{u_1, u_2 \geq 0} 4u_1 + 4u_2 \quad \text{s.t.} \quad 2u_1 + u_2 \geq 3, \quad u_1 + 2u_2 \geq 2.$$

原始点 $(x_1, x_2) = (4/3, 4/3)$ 可行, 值为 $20/3$; 对偶点 $(u_1, u_2) = (4/3, 1/3)$ 可行, 值也为 $20/3$ 。弱对偶说明二者同时最优。两项资源约束和两项产品约束均取等号, 互补松弛也逐项成立。

3.7.3 一般凸问题中的资格条件

不可行、无界和未达到必须区分。Farkas 向量证明约束不可行; 若原问题沿可行射线无限改善, 弱对偶只说明不存在给出有限下界的对偶候选, 也就是每个允许乘子的对偶函数值都为 $-\infty$, 不能据此断言乘子候选集合为空。在线性规划标准型中, 这种情形表现为对偶不可行。若只有下确界而不达到, 则不能展示原始最优点。一般凸问题在使用 Slater 条件前还需处理低维定义域。扩展实值函数 f 的**有效定义域** (effective domain) 是 $\text{dom } f = \{\mathbf{w} : f(\mathbf{w}) < +\infty\}$; 集合 C 的**仿射包** (affine hull) 是包含 C 的最小仿射集合; **相对内部** (relative interior) 则是在 $\text{aff } C$ 的相对拓扑中具有邻域的点。例如平面中的线段没有二维内部, 但去掉两个端点后就是它的相对内部。

本章采用如下 Slater 版本。设 f 和不等式函数 g_k 都是适当凸函数, 即它们不恒为 $+\infty$ 、从不取 $-\infty$ 且至少在一点取有限值; 这些函数具有共同凸定义域 D , 等式约束为仿射约束 $\mathbf{A}\mathbf{w} = \mathbf{b}$ 。若存在

$$\bar{\mathbf{w}} \in \text{ri } D, \quad \mathbf{A}\bar{\mathbf{w}} = \mathbf{b}, \quad g_k(\bar{\mathbf{w}}) < 0 \quad \text{对所有 } k,$$

并且原问题最优值有限, 则原、对偶最优值相等, 且存在最优对偶乘子。证明把可达到的“约束余量—目标值”集合与严格低于原最优值的点分离; 相对内部中的严格可行点排除了目标系数为零的异常分离向量, 归一化后便得到所需乘子。这里列出的定义域、仿射等式和有限最优值都是所采用版本的一部分。凸性本身并不够, 也不能把前面的线性规划证明原样套到任意凸问题。第 17 章会在状态、策略和价值定义后, 把同一对偶工具用于价值函数与占用度量。

3.8 松弛与最优性证书

3.8.1 凸包与可计算松弛

离散约束使可行集不再凸。例如

$$S = \{(0, 0), (1, 0), (0, 1)\}$$

可以表示“至多选择一个项目”。把 S 替换为三角形

$$\text{conv}(S) = \{(x_1, x_2) : x_1, x_2 \geq 0, x_1 + x_2 \leq 1\}$$

得到**凸松弛** (convex relaxation)：原来的每个候选仍可行，但增加了分数候选。对最小化问题，松弛最优值是原最优值的下界；对最大化问题则是上界。

精确凸包不改变任意线性目标 $\mathbf{c}^\top \mathbf{x}$ 的最优值：任意 $\mathbf{x} = \sum_i \alpha_i \mathbf{s}_i \in \text{conv}(S)$ 都满足 $\mathbf{c}^\top \mathbf{x} = \sum_i \alpha_i \mathbf{c}^\top \mathbf{s}_i \geq \min_{\mathbf{s} \in S} \mathbf{c}^\top \mathbf{s}$ ，再结合 $S \subseteq \text{conv}(S)$ 即得最小值相等，最大值同理。但它的完整不等式描述可能难以获得。只保留局部约束通常得到更大的多面体，计算较容易而界更松。也可以把乘积 $x_i x_j$ 提升为矩阵变量并要求某个块矩阵半正定，得到半正定松弛；它利用二次一致性，代价是矩阵锥约束更昂贵。

3.8.2 从界到证书

取整还可能破坏约束。考虑

$$\max_{x_1, x_2 \in \{0, 1\}} x_1 + x_2 \quad \text{s.t.} \quad 2x_1 + 2x_2 \leq 3.$$

整数最优值为 1，而把变量放宽到 $[0, 1]$ 后， $(3/4, 3/4)$ 可行且目标值为 $3/2$ 。逐坐标四舍五入得到 $(1, 1)$ ，却违反容量约束；逐坐标向下取整虽可行，却得到目标值 0。因此松弛值、恢复可行性的规则和恢复后的目标损失必须分别分析。

可计算界构成停止证书。对最小化问题，若可行解给出上界 U ，对偶或松弛给出下界 L ，则

$$0 \leq U - p^* \leq U - L.$$

当 $U = L$ 时已证明全局最优。若把松弛解取整为可行解 $\hat{\mathbf{x}}$ ，还应单独分析 $f(\hat{\mathbf{x}}) - L$ ；“取整后看起来接近”不是误差界。互补松弛能够证明哪些约束在最优点活跃，却不总能直接构造整数解。图模型中的边缘多面体和 MAP 松弛会在图与概率对象建立后复用这里的凸包、上下界和间隙概念。

3.9 非光滑目标与正则化

3.9.1 次梯度与非光滑最优性

绝对值损失和 ℓ_1 稀疏惩罚在零点不可微，但凸函数仍可用支撑直线描述。向量 $\mathbf{g}$ 若满足

$$f(\mathbf{v}) \geq f(\mathbf{u}) + \langle \mathbf{g}, \mathbf{v} - \mathbf{u} \rangle \quad \text{对所有 } \mathbf{v},$$

就称为 f 在 $\mathbf{u}$ 处的**次梯度** (subgradient)。全部次梯度组成 $\partial f(\mathbf{u})$ 。例如

$$\partial|x| = \begin{cases} \{1\}, & x > 0, \\ [-1, 1], & x = 0, \\ \{-1\}, & x < 0. \end{cases}$$

凸函数在 $\mathbf{w}^*$ 处最优，当且仅当 $\mathbf{0} \in \partial f(\mathbf{w}^*)$ 。若零向量是次梯度，定义立即给出 $f(\mathbf{v}) \geq f(\mathbf{w}^*)$ ；反过来，若 $\mathbf{w}^*$ 全局最优，则 $f(\mathbf{v}) \geq f(\mathbf{w}^*) + \langle \mathbf{0}, \mathbf{v} - \mathbf{w}^* \rangle$ ，所以零向量满足次梯度定义。这个等价性依赖凸次梯度采用全局下界定义。若要把 $f + r$ 的次微分直接写成 $\partial f + \partial r$ ，或把约束写成指标函数后拆分次微分，还需共同相对内部等相应资格条件；不能只凭两个函数都凸就无条件使用求和等式。

3.9.2 投影、邻近与软阈值

对闭凸集 C ，欧氏**投影** (projection) $\Pi_C(\mathbf{z}) = \arg \min_{\mathbf{w} \in C} \|\mathbf{w} - \mathbf{z}\|_2^2$ 把一步梯度更新拉回可行域：

$$\mathbf{w}^{(t+1)} = \Pi_C(\mathbf{w}^{(t)} - \eta_t \nabla f(\mathbf{w}^{(t)})).$$

定理 3.2 的证明已经说明，在有限维空间中，非空闭性保证最近点存在，而凸性与平方距离的严格凸性共同保证唯一。若 C 非凸，最近点可能不唯一。

更一般地，函数 r 的**邻近算子** (proximal operator) 定义为

$$\text{prox}_{\eta r}(\mathbf{z}) = \arg \min_{\mathbf{w}} \left\{ r(\mathbf{w}) + \frac{1}{2\eta} \|\mathbf{w} - \mathbf{z}\|_2^2 \right\}.$$

这里取 $\eta > 0$ ，并假设 r 是前述意义下的适当函数、下半连续且凸。二次项使目标强凸，强制性与下半连续性保证最小点存在，强凸性保证它唯一，所以邻近算子对每个 $\mathbf{z}$ 都有单值输出。指标函数 ι_C 在 C 上为零、在外部为 $+\infty$ ，其邻近算子正是投影。对 $f + r$ ，近端梯度先按光滑部分 f 走一步，再用 r 的邻近算子处理非光滑结构。

定理 3.10 ℓ_1 邻近算子是软阈值 对 $r(\mathbf{w}) = \lambda \|\mathbf{w}\|_1$,

$$[\text{prox}_{\eta r}(\mathbf{z})]_j = \text{sign}(z_j) \max\{|z_j| - \eta\lambda, 0\}.$$

证明. 目标按坐标可分, 只需最小化 $\lambda|w| + (w - z)^2/(2\eta)$ 。若 $w > 0$, 驻点为 $w = z - \eta\lambda$, 只在 $z > \eta\lambda$ 时落在该区域; 若 $w < 0$, 驻点为 $w = z + \eta\lambda$, 只在 $z < -\eta\lambda$ 时有效。若 $|z| \leq \eta\lambda$, 零点最优性条件 $0 \in \lambda[-1, 1] - z/\eta$ 成立, 所以 $w = 0$ 。合并三种情形即得结论。■

邻近算子不会放大输入距离。令 $\mathbf{p} = \text{prox}_{\eta r}(\mathbf{x})$ 、 $\mathbf{q} = \text{prox}_{\eta r}(\mathbf{y})$ 。最优性条件给出 $(\mathbf{x} - \mathbf{p})/\eta \in \partial r(\mathbf{p})$ 和 $(\mathbf{y} - \mathbf{q})/\eta \in \partial r(\mathbf{q})$ 。把两个次梯度不等式相加, 得到

$$\langle \mathbf{x} - \mathbf{y}, \mathbf{p} - \mathbf{q} \rangle \geq \|\mathbf{p} - \mathbf{q}\|_2^2.$$

再用 Cauchy-Schwarz 不等式便有 $\|\mathbf{p} - \mathbf{q}\|_2 \leq \|\mathbf{x} - \mathbf{y}\|_2$ 。这个非扩张性质依赖凸次梯度的单调性; 非凸邻近子问题可能多解, 不能直接沿用。

本节的凸次梯度也不同于第 2 章介绍的 Clarke 广义梯度。前者用一个全局仿射下界定义, 直接产生凸最优性条件; 后者取局部 Lipschitz 函数邻近可微点梯度极限的闭凸包, 允许非凸局部结构。人为指定的替代梯度更只是反向计算信号, 未必属于前面任一集合。三者名称相近, 定义对象与可用结论并不相同。

3.9.3 惩罚、约束与参数表达

惩罚与硬约束有联系, 但不是逐参数自动等价。考虑约束问题

$$\min_{\mathbf{w}} f(\mathbf{w}) \quad \text{s.t.} \quad \|\mathbf{w}\|_1 \leq R.$$

若该问题有原始最优解, 强对偶成立, 并且对偶最优乘子 λ^* 确实达到, 例如满足前述 Slater 条件且最优值有限, 则原始最优解同时最小化 $f(\mathbf{w}) + \lambda^* \|\mathbf{w}\|_1$; Lagrangian 中的常数 $-\lambda^* R$ 不影响最小点。仅有原、对偶最优值相等并不能保证这样的有限乘子存在。反过来, 不同 λ 对应的范数半径可能相同, 非凸问题还可能存在对偶间隙。把 $\mathbf{w}$ 写成其他参数的函数也会改变优化几何; 即使表示同一预测函数, 也不保证产生同一更新轨迹。

同样的区别出现在权重衰减中。普通欧氏梯度下降用于 $f(\mathbf{w}) + \lambda \|\mathbf{w}\|_2^2/2$ 时给出

$$\mathbf{w}^{(t+1)} = (1 - \eta\lambda)\mathbf{w}^{(t)} - \eta \nabla f(\mathbf{w}^{(t)}),$$

与直接乘上衰减因子相同。若使用预条件矩阵 $\mathbf{P}$, 惩罚梯度产生 $-\eta\lambda\mathbf{P}\mathbf{w}^{(t)}$, 而坐标无关的直接衰减仍为 $-\eta\lambda\mathbf{w}^{(t)}$; 除非 $\mathbf{P} = \mathbf{I}$ 或另有匹配, 它们不再相同。

3.10 随机梯度与更新稳定性

3.10.1 有限抽样与带误差迭代

有限和目标

$$F_S(\mathbf{w}) = \frac{1}{n} \sum_{i=1}^n \ell_i(\mathbf{w}) + \frac{\lambda}{2} \|\mathbf{w}\|_2^2$$

的经验损失梯度要读取全部 n 项。若 I 在 $\{1, \dots, n\}$ 上均匀抽取，则完整目标的随机梯度可取

$$\mathbf{g}_I(\mathbf{w}) = \nabla \ell_I(\mathbf{w}) + \lambda \mathbf{w}, \quad \mathbb{E}_I[\mathbf{g}_I(\mathbf{w})] = \nabla F_S(\mathbf{w}).$$

若按概率 $p_i > 0$ 非均匀抽取，则应改用

$$\mathbf{g}_I(\mathbf{w}) = \frac{\nabla \ell_I(\mathbf{w})}{np_I} + \lambda \mathbf{w}.$$

正则项梯度 $\lambda \mathbf{w}$ 是确定量，无需抽样；小批量只需平均若干经过相应加权的损失梯度，再加上这项确定梯度。小批量降低方差，却增加每步计算。

在概率工具建立前，可以先分析带确定误差的更新

$$\mathbf{w}^{(t+1)} = \mathbf{w}^{(t)} - \eta_t (\nabla F(\mathbf{w}^{(t)}) + \mathbf{e}^{(t)}).$$

若 F 为 L 光滑且 $0 < \eta_t \leq 1/L$ ，把这一步代入下降引理，并对交叉项使用 Cauchy-Schwarz 与 $2ab \leq a^2 + b^2$ ，可得

$$F(\mathbf{w}^{(t+1)}) \leq F(\mathbf{w}^{(t)}) - \frac{\eta_t}{2} \|\nabla F(\mathbf{w}^{(t)})\|_2^2 + \frac{\eta_t}{2} \|\mathbf{e}^{(t)}\|_2^2.$$

误差项因而必须与所求结论一起累计。固定非零偏差通常只允许迭代接近一个误差邻域； $\sum_t \eta_t \|\mathbf{e}^{(t)}\|_2^2 < \infty$ 使上述目标下降不等式中的累计误差项有限。仅令 $\eta_t \rightarrow 0$ 仍不够，还要核对步长总量是否足以持续纠偏，以及目标与迭代是否保持稳定。

若理想更新映射 $T_t(\mathbf{w}) = \mathbf{w} - \eta_t \nabla F(\mathbf{w})$ 是 ρ_t -Lipschitz，实际轨迹与理想轨迹之差 δ_t 满足

$$\delta_{t+1} \leq \rho_t \delta_t + \eta_t \|\mathbf{e}^{(t)}\|_2. \quad (3.19)$$

展开递推可见， $\rho_t < 1$ 时旧误差会衰减；若只有 $\rho_t \leq 1$ ，直接求和控制轨迹偏差需要考察 $\sum_t \eta_t \|\mathbf{e}^{(t)}\|_2$ ，前面的平方误差条件一般不能推出这个一次范数条件。若 $\rho_t > 1$ ，传播因子还可能放大早期扰动。减小步长降低单步误差影响，也会减慢理想更新。

3.10.2 成对迭代与梯度自界

同一递推可比较只替换一个样本的数据集 S, S' 。若每个样本梯度有界，且两条轨迹在使用相同样本时由收缩映射拉近，只在抽到被替换样本时受到

额外扰动, 就能控制 $\|\mathbf{w}_S^{(t)} - \mathbf{w}_{S'}^{(t)}\|_2$ 。具体地, 设每个样本梯度 L -Lipschitz 且范数不超过 G , 两条迭代使用相同索引 I_t 。记距离为 Δ_t ; 若 I_t 不是被替换的索引, 则

$$\Delta_{t+1} \leq (1 + \eta_t L) \Delta_t;$$

若恰好抽到被替换项, 则再增加至多 $2\eta_t G$ 。在凸光滑且步长适当时, 共同样本的梯度更新可进一步证明为非扩张映射, 从而去掉前式中的膨胀因子。这称为 **算法稳定性** (algorithmic stability): 训练集改动一个样本时, 输出不会变化太大。完整的期望界和随机收敛需使用第 9 章的条件期望与噪声工具。

缩放损失会等比例缩放梯度, 因此学习率不能脱离损失尺度比较。梯度裁剪把过大更新限制在指定半径内, 改变了估计量并可能引入偏差。对更新式直接减去 $\eta\lambda\mathbf{w}$ 的权重衰减, 在普通梯度下降中等价于 ℓ_2 惩罚; 使用坐标自适应缩放时, 两者通常不再等价。

引理 3.11 非负光滑函数的梯度自界 若 $\ell: \mathbb{R}^d \rightarrow [0, \infty)$ 可微且 L 光滑, 则

$$\|\nabla \ell(\mathbf{w})\|_2^2 \leq 2L\ell(\mathbf{w}).$$

证明. 在下降引理中取 $\mathbf{v} = \mathbf{w} - \nabla \ell(\mathbf{w})/L$, 得到

$$\ell(\mathbf{v}) \leq \ell(\mathbf{w}) - \frac{1}{2L} \|\nabla \ell(\mathbf{w})\|_2^2.$$

左侧非负, 移项即得结论。若损失可取负值, 这一步失效; 给函数加常数虽不改变梯度, 却会改变右侧, 所以非负性是实质条件。 ■

3.11 分块、交替与分布优化

3.11.1 分块更新与约束分解

若变量自然分成 $\mathbf{u}$ 与 $\mathbf{v}$ 两组, 可以固定一组更新另一组。对

$$\Phi(\mathbf{u}, \mathbf{v}) = \frac{1}{2} \|\mathbf{X}\mathbf{u} + \mathbf{Z}\mathbf{v} - \mathbf{y}\|_2^2 + r(\mathbf{u}) + s(\mathbf{v}),$$

分块坐标法 (block coordinate method) 每次只对一个块走梯度或近端步; **交替最小化** (alternating minimization) 则精确或近似求解每个块的条件子问题。若每次子问题确实降低同一个 Φ , 目标值单调不减。精确交替最小化时, 这一点直接来自

$$\Phi(\mathbf{u}^{(t+1)}, \mathbf{v}^{(t)}) \leq \Phi(\mathbf{u}^{(t)}, \mathbf{v}^{(t)}), \quad \Phi(\mathbf{u}^{(t+1)}, \mathbf{v}^{(t+1)}) \leq \Phi(\mathbf{u}^{(t+1)}, \mathbf{v}^{(t)}).$$

但非凸情形下仍可能停在局部解或依赖初始化。

一个可复核的耦合二次例子是

$$\Phi(u, v) = \frac{1}{2}(u - v)^2 + \frac{1}{2}(u - 1)^2.$$

固定 v 时的唯一最优点为 $u = (v + 1)/2$, 固定 u 时的唯一最优点为 $v = u$ 。从 $v^{(0)}$ 出发, 一轮交替更新得到 $u^{(t+1)} = (v^{(t)} + 1)/2$ 、 $v^{(t+1)} = u^{(t+1)}$, 因而 $v^{(t+1)} - 1 = (v^{(t)} - 1)/2$, 最终到达联合最优点 $(1, 1)$ 。这里的收敛来自这个正定二次目标的特殊结构。换成非凸目标 $(uv - 1)^2$ 并从 $(0, 0)$ 开始时, 逐块目标在一块固定为零时没有提供离开零点的理由; 若平局规则继续选择零, 目标保持为 1, 而全局最优值为 0。所以逐块精确和目标单调都不单独保证全局最优。

约束耦合时, 可以复制共享变量, 再通过一致性约束分解为局部子问题。乘子负责协调副本, 这改变了每步计算位置, 却没有删除原约束。若局部问题没有被足够准确地求解, 或协调步长不满足条件, 分解形式本身不保证收敛。

3.11.2 代理函数与单调改善

主化-最小化方法 (majorization-minimization, MM) 在当前点 $\mathbf{w}^{(t)}$ 构造代理函数 $Q(\mathbf{w} | \mathbf{w}^{(t)})$, 满足

$$F(\mathbf{w}) \leq Q(\mathbf{w} | \mathbf{w}^{(t)}), \quad F(\mathbf{w}^{(t)}) = Q(\mathbf{w}^{(t)} | \mathbf{w}^{(t)}).$$

若 $\mathbf{w}^{(t+1)}$ 使代理函数不增, 则

$$\begin{aligned} F(\mathbf{w}^{(t+1)}) &\leq Q(\mathbf{w}^{(t+1)} | \mathbf{w}^{(t)}) \\ &\leq Q(\mathbf{w}^{(t)} | \mathbf{w}^{(t)}) = F(\mathbf{w}^{(t)}). \end{aligned}$$

第一步用全局上界, 第二步用代理改善, 最后一步用切触条件。若代理只在当前点附近控制原目标, 而新点走出该邻域, 单调链条便会断裂。

下降引理本身给出一个显式代理。若 F 为 L 光滑, 可取

$$Q(\mathbf{w} | \mathbf{w}^{(t)}) = F(\mathbf{w}^{(t)}) + \langle \nabla F(\mathbf{w}^{(t)}), \mathbf{w} - \mathbf{w}^{(t)} \rangle + \frac{L}{2} \|\mathbf{w} - \mathbf{w}^{(t)}\|_2^2.$$

它在当前点切触并全局上界 F ; 精确最小化 Q 恰好得到步长 $1/L$ 的梯度更新。仅让代理与原目标在当前点具有相同梯度, 却不满足全局上界, 不能推出上面的单调不等式链。

变量也可以是一个分布 q 。此时“更新分布”仍是在某个可行分布集合上降低同一目标, 而非一种脱离优化的概率操作。在有限支持 $\{1, \dots, m\}$ 上,

分布变量就是概率单纯形

$$\Delta_m = \{\mathbf{q} \in \mathbb{R}^m : q_i \geq 0, \sum_{i=1}^m q_i = 1\}.$$

归一化、非负性和支持集都是可行约束，更新后必须仍留在这个单纯形中。EM 与变分方法还需要期望、条件分布和散度。第 8 章、第 10 章和第 11 章建立这些对象后，将复用交替优化与 MM 的单调性核对方式。

3.12 多目标与鞍点

3.12.1 支配、Pareto 与共同下降

两个任务可能产生损失向量 $\mathbf{f}(\mathbf{w}) = (f_1(\mathbf{w}), f_2(\mathbf{w}))$ 。若一个方案两项都不差且至少一项更好，就称它**支配** (dominate) 另一个方案。不可被任何可行方案支配的点称为 **Pareto 最优** (Pareto optimal)。这是一种偏序，而不是单一排名。

加权和 $\alpha f_1 + (1 - \alpha)f_2$ 把偏好写成一个标量目标， $\alpha \in [0, 1]$ 。它能找出凸目标像边界上的支撑点，但非凸 Pareto 前沿的某些点无法由任何固定权重得到。例如三个可行方案的损失向量分别为 $(0, 1)$ 、 $(1, 0)$ 和 $(0.6, 0.6)$ 。第三个方案不被前两个方案支配，所以是 Pareto 最优；但对任意 $\alpha \in [0, 1]$ ，前两个方案的加权损失中至少一个不超过 0.5，严格小于第三个方案的 0.6，故权重和永远不会选择第三个方案。在当前点，方向 $\mathbf{d}$ 若满足

$$\langle \nabla f_1(\mathbf{w}), \mathbf{d} \rangle < 0, \quad \langle \nabla f_2(\mathbf{w}), \mathbf{d} \rangle < 0,$$

就是**共同下降方向** (common descent direction)。寻找最小范数凸组合 $\alpha \nabla f_1 + (1 - \alpha) \nabla f_2$ 相当于把原点投影到两梯度的线段上。

定理 3.12 无共同下降方向的一阶判定 对可微的 m 个目标，在无约束点 $\mathbf{w}$ 处不存在共同严格下降方向，当且仅当存在 $\alpha_i \geq 0$ 、 $\sum_i \alpha_i = 1$ ，使 $\sum_i \alpha_i \nabla f_i(\mathbf{w}) = \mathbf{0}$ 。

证明. 若这样的凸组合存在，而 $\mathbf{d}$ 使每个内积都为负，则加权和内积也为负，与零向量矛盾。反之，若原点不在梯度集合的凸包中，定理 3.2 给出 $\mathbf{d}$ ，使它与每个梯度的内积具有同一严格符号；必要时取 $-\mathbf{d}$ ，便得到共同严格下降方向。 ■

这个条件只排除局部的一阶共同改善，不保证全局 Pareto 最优；高阶变化或远处方案仍可能同时改善所有目标。

3.12.2 极小极大与鞍点间隙

另一类问题让两个变量方向相反：

$$\min_{\mathbf{w} \in W} \max_{\mathbf{z} \in Z} \phi(\mathbf{w}, \mathbf{z}).$$

点 $(\mathbf{w}^*, \mathbf{z}^*)$ 若满足

$$\phi(\mathbf{w}^*, \mathbf{z}) \leq \phi(\mathbf{w}^*, \mathbf{z}^*) \leq \phi(\mathbf{w}, \mathbf{z}^*)$$

就称为**极小极大鞍点**（minimax saddle point）。这里“鞍点”描述两个变量承担相反优化方向时的全局比较关系，不是第2.5节中由单个标量函数的驻点和 Hessian 矩阵正负曲率定义的微分鞍点。微分鞍点未必求解某个极小极大问题；极小极大鞍点位于边界或目标不可微时，也未必满足驻点与 Hessian 判据。对任意候选对定义

$$P(\mathbf{w}) = \sup_{\mathbf{z} \in Z} \phi(\mathbf{w}, \mathbf{z}), \quad D(\mathbf{z}) = \inf_{\mathbf{w} \in W} \phi(\mathbf{w}, \mathbf{z}).$$

总有 $D(\mathbf{z}) \leq P(\mathbf{w})$ ，所以 $P(\mathbf{w}) - D(\mathbf{z}) \geq 0$ 是**原始-对偶间隙**（primal-dual gap）；间隙为零时，该候选对满足鞍点不等式。

本章采用以下有限维极小极大版本：若 W, Z 非空、紧且凸， ϕ 连续，对固定 $\mathbf{z}$ 的 $\phi(\cdot, \mathbf{z})$ 为凸函数，对固定 $\mathbf{w}$ 的 $\phi(\mathbf{w}, \cdot)$ 为凹函数，则

$$\min_{\mathbf{w} \in W} \max_{\mathbf{z} \in Z} \phi(\mathbf{w}, \mathbf{z}) = \max_{\mathbf{z} \in Z} \min_{\mathbf{w} \in W} \phi(\mathbf{w}, \mathbf{z}),$$

且两侧最值达到。紧致性提供最值的达到，凸凹性允许用分离比较混合候选，连续性保证极限不丢失函数值。鲁棒优化中的 $\mathbf{z}$ 表示最坏扰动，对抗训练让扰动方提高损失，多任务协调则可能在权重与模型间形成极小极大结构。若缺少上述条件，两个优化次序可能不同；即使值相等，具体梯度下降-上升仍可能旋转或发散，值的存在定理不等于算法收敛定理。

3.13 双层目标与隐式更新

3.13.1 展开有限次更新

有些决策必须先经过一次学习过程才能评价。令外层变量为 θ 。如果内层问题有多个最小点，只写 $\mathbf{w}^*(\theta) \in \arg \min_{\mathbf{w}} L_{\text{in}}(\mathbf{w}, \theta)$ 并不能定义一个单值映射，不同最小点还可能给出不同的外层损失。此时可以分别把最小点集合上的最小、最大外层损失定义为乐观、悲观值，也可以给定由初始化和算法路径决定的单值选择规则。下文假设内层最小解唯一，或已经给定单

值选择 S ，并记

$$\mathbf{w}^*(\theta) = S(\theta) \in \arg \min_{\mathbf{w}} L_{\text{in}}(\mathbf{w}, \theta).$$

于是外层目标

$$J(\theta) = L_{\text{out}}(\mathbf{w}^*(\theta), \theta). \quad (3.20)$$

这就是**双层优化** (bilevel optimization)。元学习把内层看成任务适应，超参数选择让 θ 控制正则强度或数据权重，定向知识修正则让外层评价修改后的特定行为。

一种求导方式是吧 T 步内层更新全部展开。例如 $\mathbf{w}^{(t+1)} = \mathbf{w}^{(t)} - \eta \nabla_{\mathbf{w}} L_{\text{in}}(\mathbf{w}^{(t)}, \theta)$ ，再按链式法则从 $t = T$ 反向传播。展开法忠实求导于“运行 T 步”这个实际算法，但存储随 T 增长，且所得梯度对应近似内层解，不一定对应精确最优解。

两步展开已经能看清链式结构。记

$$\mathbf{A}_t = \mathbf{I} - \eta \nabla_{\mathbf{w}\mathbf{w}}^2 L_{\text{in}}(\mathbf{w}^{(t)}, \theta), \quad \mathbf{B}_t = \nabla_{\mathbf{w}\theta}^2 L_{\text{in}}(\mathbf{w}^{(t)}, \theta).$$

则

$$\frac{d\mathbf{w}^{(t+1)}}{d\theta} = \mathbf{A}_t \frac{d\mathbf{w}^{(t)}}{d\theta} - \eta \mathbf{B}_t,$$

从而

$$\frac{d\mathbf{w}^{(2)}}{d\theta} = \mathbf{A}_1 \mathbf{A}_0 \frac{d\mathbf{w}^{(0)}}{d\theta} - \eta \mathbf{A}_1 \mathbf{B}_0 - \eta \mathbf{B}_1.$$

外层梯度再把这个 Jacobian 与 $\nabla_{\mathbf{w}} L_{\text{out}}$ 相乘，并加上外层目标对 θ 的直接偏导。截断某一步会删除相应乘积项，因而改变所求导的算法，而不只是节省存储。

3.13.2 对局部内层解隐式求导

隐式求导跟踪的是一个选定的非退化局部最小点分支，不自动证明该分支实现全局最小值。只有当这个分支也是全局最小点并符合前述选择规则时，它才与 $\mathbf{w}^*(\theta)$ 及 J 对应。为区分两者，记局部分支及其外层目标为 $\hat{\mathbf{w}}(\theta)$ 和 $\hat{J}(\theta) = L_{\text{out}}(\hat{\mathbf{w}}(\theta), \theta)$ 。若 L_{in} 二阶连续可微，并且

$$\nabla_{\mathbf{w}} L_{\text{in}}(\hat{\mathbf{w}}(\theta), \theta) = \mathbf{0},$$

记在该分支上计算的二阶导数为 $\mathbf{H}_{\mathbf{w}\mathbf{w}} = \nabla_{\mathbf{w}\mathbf{w}}^2 L_{\text{in}}$ 和 $\mathbf{H}_{\mathbf{w}\theta} = \nabla_{\mathbf{w}\theta}^2 L_{\text{in}}$ 。对驻点方程关于 θ 求导得到

$$\mathbf{H}_{\mathbf{w}\mathbf{w}} \frac{d\hat{\mathbf{w}}}{d\theta} + \mathbf{H}_{\mathbf{w}\theta} = \mathbf{0}.$$

当 $\mathbf{H}_{ww}$ 可逆时，隐函数定理给出局部可微分支；对非退化局部最小点， $\mathbf{H}_{ww} > \mathbf{0}$ 保证这一可逆性。链式法则于是给出

$$\nabla_{\theta} \hat{J} = \nabla_{\theta} L_{\text{out}} - \mathbf{H}_{w\theta}^{\top} \mathbf{H}_{ww}^{-\top} \nabla_w L_{\text{out}}. \quad (3.21)$$

式 (3.21) 是**隐式超梯度** (implicit hypergradient)。实际计算通常解线性方程 $\mathbf{H}_{ww}^{\top} \mathbf{v} = \nabla_w L_{\text{out}}$ ，无须显式求逆。

用二次内层目标可以核对公式。设 $\mathbf{H} > \mathbf{0}$,

$$L_{\text{in}}(\mathbf{w}, \theta) = \frac{1}{2}(\mathbf{w} - \mathbf{B}\theta)^{\top} \mathbf{H}(\mathbf{w} - \mathbf{B}\theta), \quad L_{\text{out}}(\mathbf{w}) = \frac{1}{2}\|\mathbf{C}\mathbf{w} - \mathbf{d}\|_2^2.$$

这里内层最小点唯一，因此局部分支与全局选择一致： $\hat{\mathbf{w}} = \mathbf{w}^* = \mathbf{B}\theta$ 且 $\hat{J} = J$ 。直接消元给出

$$\nabla_{\theta} J = \mathbf{B}^{\top} \mathbf{C}^{\top} (\mathbf{C}\mathbf{B}\theta - \mathbf{d}).$$

隐式公式中 $\mathbf{H}_{ww} = \mathbf{H}$ 、 $\mathbf{H}_{w\theta} = -\mathbf{H}\mathbf{B}$ ，代入后得到同一结果。计算时若线性方程残差为 $\mathbf{r}$ ，解误差为 $\mathbf{H}^{-\top} \mathbf{r}$ ；小特征值会放大该误差。因而内层驻点残差、线性求解残差和曲率病态是三种不同的误差来源。

若内层只近似收敛，驻点残差会进入超梯度误差；若 Hessian 矩阵奇异，解映射可能不唯一或不可微；若内层非凸，所选局部分支还依赖初始化与算法路径，并且可能不是全局最小点。后一种情况下，式 (3.21) 给出的是 $\hat{J}$ 的梯度，而不是前述全局双层目标 J 的梯度。展开深度、线性方程精度、内层计算预算与解选择规则因此都是问题定义的一部分，而不只是实现细节。

3.14 本章小结

最优化需要分别回答四个问题：候选解是否存在，某个点为何最优，算法怎样到达它，以及误差按什么尺度收敛。连续性配合紧致性保证存在；在闭域上，下半连续性与强制性也能通过紧下水平集保证存在。凸性把局部条件提升为全局条件，强凸、光滑性与 PL 条件则分别控制参数距离、单步上界和目标误差。它们不能只用“曲率好”一语合并。

带资源约束后，KKT 条件描述目标梯度与约束法向量的平衡，对偶变量提供界和敏感性解释。Farkas 证书与线性规划强对偶说明最优值相等需要证明，不能从凸性直接跳得。松弛、对偶界与可行解共同形成最优性证书；证书说明结果离最优值多远，却不自动给出寻找结果的过程。

非光滑正则需要次梯度、投影或邻近算子，不完整梯度需要核对误差如何累计。分块、分布变量、多目标、鞍点与双层目标改变的是变量组织和最优性概念，不能沿用同一套无条件保证。随机更新的严格收敛将在第 9 章

建立条件期望与噪声工具后补全；后续决策章节还会复用本章的对偶与鞍点语言。紧邻的第 4 章将把有限维参数推广到函数空间，区分表示存在性、逼近误差与函数类复杂度。

第 4 章

泛函分析与逼近理论

有限维模型常把函数写成固定基函数的线性组合：

$$f_m(x) = \sum_{j=1}^m a_j \phi_j(x). \quad (4.1)$$

当 m 固定时，可以把系数 $(a_1, \dots, a_m)^\top$ 当作普通向量，用欧氏距离比较两个候选解。然而，一旦允许基函数数目增加，系数向量所在的维数也随之改变；同一个函数还可能在不同基下拥有完全不同的系数。此时，仅比较参数向量已经不能稳定地回答三个问题：函数之间相差多少，有限表示能否逼近目标，以及从数据选择出的函数有多复杂。

本章改为直接把函数看成空间中的点。范数规定误差怎样度量，完备性保证逼近序列的极限仍在空间内，内积则把有限维最小二乘中的正交与投影推广到函数。若还要求能够连续地读取函数在某个输入处的值，就会得到再生核 Hilbert 空间（reproducing kernel Hilbert space, RKHS）。在此基础上，我们再区分表示能力与函数类大小：前者问某个目标能否被逼近，后者问候选函数可以沿多少方向、以多细尺度变化。这一区分将在后续概率章节中进入有限观测误差，但本章只建立其中不依赖随机抽样的空间结构。

4.1 函数作为空间中的对象

4.1.1 逐点运算给出线性结构

设 $\mathcal{X}$ 为输入集合， $\mathbb{R}^{\mathcal{X}}$ 表示从 $\mathcal{X}$ 到 $\mathbb{R}$ 的全部函数。对 $f, g \in \mathbb{R}^{\mathcal{X}}$ 和 $a, b \in \mathbb{R}$ ，定义

$$(af + bg)(x) = af(x) + bg(x), \quad x \in \mathcal{X}.$$

这些逐点运算使 $\mathbb{R}^{\mathcal{X}}$ 成为向量空间。式 (4.1) 描述的集合只是其中由 $\phi_1, \dots, \phi_m$ 张成的有限维子空间。允许无限多个基方向以后，线性结构仍然存在，但坐标数目不再适合作为唯一的大小尺度。

赋范空间 (normed space) 是在向量空间 $\mathcal{V}$ 上配备范数 $\|\cdot\|_{\mathcal{V}}$ 的空间。范数对 $f, g \in \mathcal{V}$ 和标量 a 满足

$$\|f\|_{\mathcal{V}} \geq 0, \quad \|f\|_{\mathcal{V}} = 0 \iff f = 0, \quad \|af\|_{\mathcal{V}} = |a|\|f\|_{\mathcal{V}},$$

以及三角不等式 $\|f + g\|_{\mathcal{V}} \leq \|f\|_{\mathcal{V}} + \|g\|_{\mathcal{V}}$ 。距离由 $d(f, g) = \|f - g\|_{\mathcal{V}}$ 给出。选择不同范数, 就是选择不同的误差含义。

例如, 紧区间 $[a, b]$ 上的连续函数空间 $C([a, b])$ 常使用一致范数

$$\|f\|_{\infty} = \sup_{x \in [a, b]} |f(x)|.$$

这个范数控制每个输入上的最大误差。若 μ 是一个测度, 则第 2 章建立的 $L^p(\mu)$ 空间使用

$$\|f\|_{L^p(\mu)} = \left(\int_{\mathcal{X}} |f(x)|^p d\mu(x) \right)^{1/p}, \quad 1 \leq p < \infty.$$

它控制的是相对于 μ 的整体误差, 允许函数在小测度集合上偏离较大。两种误差不能互相替代: 在 $[0, 1]$ 上令

$$f_n(x) = \max\{1 - nx, 0\},$$

则 $\|f_n\|_{L^2}^2 = 1/(3n) \rightarrow 0$, 但 $\|f_n\|_{\infty} = 1$ 始终不变。

后面的完备性证明会用到 L^2 版本的**Minkowski 不等式** (Minkowski inequality), 也就是 L^2 范数的三角不等式。对 $f, g \in L^2(\mu)$, Cauchy-Schwarz 不等式给出

$$\begin{aligned} \|f + g\|_{L^2(\mu)}^2 &= \|f\|_{L^2(\mu)}^2 + 2 \int_{\mathcal{X}} f(x)g(x) d\mu(x) + \|g\|_{L^2(\mu)}^2 \\ &\leq (\|f\|_{L^2(\mu)} + \|g\|_{L^2(\mu)})^2. \end{aligned}$$

两边开平方便得到 $\|f + g\|_{L^2(\mu)} \leq \|f\|_{L^2(\mu)} + \|g\|_{L^2(\mu)}$; 反复使用即可控制有限个函数之和。

4.1.2 完备性保证极限没有逃出空间

赋范空间中的序列 (f_n) 若满足: 对每个 $\varepsilon > 0$, 存在 N , 使 $m, n \geq N$ 时都有 $\|f_m - f_n\|_{\mathcal{V}} < \varepsilon$, 就称为柯西序列。若每个柯西序列都收敛到 $\mathcal{V}$ 中的元素, 则 $\mathcal{V}$ 称为**Banach 空间** (Banach space)。完备性不负责证明某个具体序列是柯西序列; 它只保证一旦误差足以让序列内部彼此靠近, 极限不会落到空间之外。

区间 $[a, b]$ 上的 $C([a, b])$ 配备一致范数是 Banach 空间。事实上, 若 (f_n)

在一致范数下为柯西序列, 那么每个 x 处的 $(f_n(x))$ 都是实数柯西序列, 可以定义 $f(x) = \lim_n f_n(x)$ 。柯西条件对所有 x 使用同一个 N , 故 f_n 一致收敛到 f ; 连续函数的一致极限仍连续, 所以 $f \in C([a, b])$ 。

同一个函数集合换一种范数可能失去完备性。连续函数空间 $C([0, 1])$ 配备 L^2 范数就不是完备的。取连续函数 f_n 逐渐逼近阶跃函数 $\mathbb{I}_{\{x > 1/2\}}$, 可以使 (f_n) 在 L^2 中为柯西序列, 但它的 L^2 极限没有任何处处连续的代表元。完成这个空间需要加入可测函数的几乎处处等价类, 得到 $L^2([0, 1])$ 。这里“几乎处处等价”很关键: 如果 f 与 g 只在零测集上不同, 它们在 L^2 中是同一个元素。

$L^2(\mu)$ 本身的完备性可以从柯西列内部构造极限。设 (f_n) 在 $L^2(\mu)$ 中为柯西列。逐次选取子列 (f_{n_k}) , 使

$$\|f_{n_{k+1}} - f_{n_k}\|_{L^2(\mu)} \leq 2^{-k}.$$

令 $h_k = |f_{n_{k+1}} - f_{n_k}|$ 。对有限部分和反复使用上面的 L^2 版 Minkowski 不等式, 再用 Fatou 引理, 可得

$$\int_{\mathcal{X}} \left(\sum_{k=1}^{\infty} h_k \right)^2 d\mu \leq \left(\sum_{k=1}^{\infty} 2^{-k} \right)^2 < \infty.$$

因此 $\sum_k h_k(x)$ 几乎处处有限, $(f_{n_k}(x))$ 在这些点绝对收敛。把它的几乎处处极限记为 f 。同样对尾和使用 Fatou 引理, 得到

$$\|f_{n_\ell} - f\|_{L^2(\mu)} \leq \sum_{k=\ell}^{\infty} 2^{-k} \longrightarrow 0.$$

原序列是柯西列, 故它与已收敛子列的距离也趋于零, 从而 $f_n \rightarrow f$ 于 $L^2(\mu)$ 。这个论证同时说明为何要把只在零测集上不同的代表元视为同一元素: 构造得到的点态极限本来就只在几乎处处意义下确定。对 $1 \leq p < \infty$ 可用相同的可求和子列思路证明 $L^p(\mu)$ 完备; $p = \infty$ 时则控制本质上确界。因此, $1 \leq p \leq \infty$ 时的 $L^p(\mu)$ 都是 Banach 空间, 而 $L^2(\mu)$ 还具有下面要用的内积结构。

4.1.3 内积把长度与正交联系起来

内积空间 (inner-product space) 在实向量空间 $\mathcal{V}$ 上配备对称双线性映射 $\langle \cdot, \cdot \rangle_{\mathcal{V}}$, 并要求 $\langle f, f \rangle_{\mathcal{V}} > 0$ 对每个非零 f 成立。内积诱导范数

$$\|f\|_{\mathcal{V}} = \sqrt{\langle f, f \rangle_{\mathcal{V}}}.$$

相应范数下完备的内积空间称为 **Hilbert 空间** (Hilbert space)。它把欧氏空间中长度、夹角、正交和投影的关系保留下来, 同时允许空间无限维。

$L^2(\mu)$ 是基本例子，其内积为

$$\langle f, g \rangle_{L^2(\mu)} = \int_x f(x)g(x) d\mu(x).$$

但 $L^1(\mu)$ 与一般的 $L^p(\mu)$ 并不都由内积诱导。一个范数来自内积，当且仅当它满足 **平行四边形恒等式** (parallelogram identity)

$$\|f + g\|^2 + \|f - g\|^2 = 2\|f\|^2 + 2\|g\|^2. \quad (4.2)$$

例如在 $\mathbb{R}^2$ 的 L^1 范数中取 $\mathbf{u} = (1, 0)^\top$ 、 $\mathbf{v} = (0, 1)^\top$ ，左侧为 8，右侧为 4，所以这个范数不可能来自内积。Banach 空间提供极限与距离，Hilbert 空间额外提供正交几何；后面的投影结论依赖后者，不能只靠完备范数得到。

无限维还使一些有限维中自动成立的性质需要单独检查。有限维子空间总是闭集，有界序列总能抽出收敛子列，线性映射也自动连续；这些陈述在一般无限维空间中都可能失效。例如 ℓ^2 中的标准单位向量 $(\mathbf{e}_j)_{j \geq 1}$ 都位于单位球内，但 $j \neq k$ 时

$$\|\mathbf{e}_j - \mathbf{e}_k\|_2 = \sqrt{2}.$$

这个序列没有柯西子列，因而也没有收敛子列。无限维闭单位球由此给出“闭且有界未必紧”的具体反例；这里具体指 ℓ^2 的闭单位球。

完备性与稠密性也不能混为一谈。 ℓ^2 由平方可和序列 $\mathbf{a} = (a_1, a_2, \dots)$ 组成，范数为 $\|\mathbf{a}\|_2^2 = \sum_{j=1}^{\infty} a_j^2$ 。只有有限个非零坐标的序列构成子空间 c_{00} ，它在 ℓ^2 中稠密却不闭。序列 $(1, 1/2, \dots, 1/n, 0, \dots)$ 属于 c_{00} ，其极限 $(1, 1/2, 1/3, \dots)$ 属于 ℓ^2 但不属于 c_{00} 。这正是闭性在最佳逼近问题中不能省略的原因。有限截断能够不断逼近 ℓ^2 中的元素，说明 c_{00} 的闭包是 ℓ^2 ；它并不说明 c_{00} 自身已经包含这些极限。

4.2 正交展开与函数投影

4.2.1 闭凸集上的最近点

有限维最小二乘把观测向量投影到设计矩阵的列空间。函数逼近的对应问题是：给定 Hilbert 空间 $\mathcal{H}$ 中的目标 f 与候选集合 C ，能否找到 $g^* \in C$ 使 $\|f - g^*\|_{\mathcal{H}}$ 最小？下面的投影定理中，非空性只保证距离下确界有候选可比较；凸性与内积几何先使最小化序列成为柯西列，Hilbert 空间的完备性保证该序列在空间中有极限，闭性再把极限留在 C 内。凸性还参与唯一性与变分不等式的证明，因而不能把四项条件各自简化成互不相干的一项职责。

定理 4.1 Hilbert 空间投影定理 设 $\mathcal{H}$ 为实 Hilbert 空间, $C \subseteq \mathcal{H}$ 非空、闭且凸。对每个 $f \in \mathcal{H}$, 存在唯一的 $g^* \in C$ 满足

$$\|f - g^*\|_{\mathcal{H}} = \inf_{g \in C} \|f - g\|_{\mathcal{H}}.$$

这个最近点由变分不等式

$$\langle f - g^*, g - g^* \rangle_{\mathcal{H}} \leq 0, \quad g \in C \quad (4.3)$$

唯一刻画。若 $C = M$ 是闭线性子空间, 则该条件等价于

$$f - g^* \perp M. \quad (4.4)$$

证明. 记 $d = \inf_{g \in C} \|f - g\|_{\mathcal{H}}$, 并取最小化序列 $(g_n) \subseteq C$, 使 $\|f - g_n\|_{\mathcal{H}} \rightarrow d$ 。凸性保证 $(g_n + g_m)/2 \in C$ 。把平行四边形恒等式用于 $f - g_n$ 与 $f - g_m$, 得到

$$\begin{aligned} \|g_n - g_m\|_{\mathcal{H}}^2 &= 2\|f - g_n\|_{\mathcal{H}}^2 + 2\|f - g_m\|_{\mathcal{H}}^2 \\ &\quad - 4\left\|f - \frac{g_n + g_m}{2}\right\|_{\mathcal{H}}^2 \\ &\leq 2\|f - g_n\|_{\mathcal{H}}^2 + 2\|f - g_m\|_{\mathcal{H}}^2 - 4d^2. \end{aligned}$$

右侧随 $m, n \rightarrow \infty$ 趋于 0, 所以 (g_n) 是柯西序列。 $\mathcal{H}$ 完备, 故 $g_n \rightarrow g^* \in \mathcal{H}$; C 闭, 故 $g^* \in C$ 。范数连续给出 $\|f - g^*\|_{\mathcal{H}} = d$, 存在性得证。

若 $g_1, g_2 \in C$ 都达到 d , 同一恒等式给出

$$\|g_1 - g_2\|_{\mathcal{H}}^2 = 2d^2 + 2d^2 - 4\left\|f - \frac{g_1 + g_2}{2}\right\|_{\mathcal{H}}^2 \leq 0,$$

所以 $g_1 = g_2$ 。

再证明刻画。对任意 $g \in C$ 和 $t \in [0, 1]$, 凸性给出 $g^* + t(g - g^*) \in C$ 。最优性意味着

$$\|f - g^*\|_{\mathcal{H}}^2 \leq \|f - g^* - t(g - g^*)\|_{\mathcal{H}}^2.$$

展开右侧、约去公共项并除以 $t > 0$, 得到

$$2\langle f - g^*, g - g^* \rangle_{\mathcal{H}} \leq t\|g - g^*\|_{\mathcal{H}}^2.$$

令 $t \downarrow 0$ 便得到式 (4.3)。反过来, 若该不等式成立, 则对任意 $g \in C$,

$$\|f - g\|_{\mathcal{H}}^2 = \|f - g^*\|_{\mathcal{H}}^2 + \|g - g^*\|_{\mathcal{H}}^2 - 2\langle f - g^*, g - g^* \rangle_{\mathcal{H}} \geq \|f - g^*\|_{\mathcal{H}}^2,$$

所以 g^* 是最近点。

若 $C = M$ 为线性子空间，则对每个 $h \in M$ ，可分别取 $g = g^* + h$ 和 $g = g^* - h$ 。式 (4.3) 同时给出 $\langle f - g^*, h \rangle \leq 0$ 与 $-\langle f - g^*, h \rangle \leq 0$ ，故内积为零。反向结论由勾股恒等式直接得到。 ■

闭性不能由“子空间”二字自动获得。以前面的 $c_{00} \subset \ell^2$ 为例，目标 $\mathbf{a} = (1, 1/2, 1/3, \dots)$ 到 c_{00} 的距离下确界为 0，但 $\mathbf{a} \notin c_{00}$ ，所以不存在最佳逼近。有限截断可以任意接近目标，却没有一个有限截断达到距离 0。

4.2.2 正交系数把逼近误差分解开

设 $(e_j)_{j \geq 1}$ 是 $\mathcal{H}$ 中的正交归一序列，即 $\langle e_j, e_k \rangle_{\mathcal{H}} = \mathbb{I}\{j = k\}$ 。目标 f 在前 m 个方向上的投影为

$$P_m f = \sum_{j=1}^m \langle f, e_j \rangle_{\mathcal{H}} e_j. \quad (4.5)$$

因为 $f - P_m f$ 与每个 e_j 正交，定理 4.1 说明 $P_m f$ 是 $\text{span}\{e_1, \dots, e_m\}$ 中的唯一最佳逼近。勾股恒等式进一步给出

$$\|f - P_m f\|_{\mathcal{H}}^2 = \|f\|_{\mathcal{H}}^2 - \sum_{j=1}^m |\langle f, e_j \rangle_{\mathcal{H}}|^2. \quad (4.6)$$

左侧非负，于是得到 Bessel 不等式 $\sum_{j \geq 1} |\langle f, e_j \rangle|^2 \leq \|f\|^2$ 。若 (e_j) 的线性张成在 $\mathcal{H}$ 中稠密，就称 (e_j) 为 $\mathcal{H}$ 的 **完备正交系** (complete orthonormal system)。这个定义等价于：若 $f \in \mathcal{H}$ 与每个 e_j 都正交，则 $f = 0$ 。此时 $P_m f \rightarrow f$ ，上式成为 Parseval 恒等式。“系数可平方求和”与“展开恢复整个函数”之间差的正是所选正交系是否完备，也就是它是否遗漏了与所有 e_j 正交的非零方向。

正交系的完备性与 Hilbert 空间的完备性不是同一性质。前者考察一组给定方向能否稠密张成整个空间，后者考察任意柯西序列的极限是否仍在空间内。例如 ℓ^2 是完备的 Hilbert 空间，但只取 $(e_{2j})_{j \geq 1}$ 会遗漏所有奇数坐标方向，因此这组正交归一向量不是完备正交系。

4.2.3 权重改变什么叫作最佳逼近

设 w 是 $[-1, 1]$ 上可测、几乎处处为正且属于 $L^1([-1, 1])$ 的权重。在关于测度 $w(x)dx$ 的几乎处处等价类所成空间 $L^2([-1, 1], w(x)dx)$ 上，定义

$$\langle f, g \rangle_w = \int_{-1}^1 f(x)g(x)w(x)dx.$$

加权平方可积性与 Cauchy-Schwarz 不等式保证该积分对空间中任意 f, g 有限；权重几乎处处为正则保证它确实定义内积。由于紧区间上的多项

式有界, 而 w 可积, 每个多项式都属于这个加权空间, 因此可以对幂函数序列作 Gram-Schmidt 正交化。权重 $w(x) = 1$ 对应 Legendre 多项式; 权重 $w(x) = (1 - x^2)^{-1/2}$ (端点值任取) 对应第一类 Chebyshev 多项式 $T_j(x) = \cos(j \arccos x)$ 。后者在 $x = \pm 1$ 附近赋予更大权重, 因此相同次数的投影优化的是另一种积分误差。

只保留计算展开所需的低阶关系即可。Legendre 多项式满足

$$P_0(x) = 1, \quad P_1(x) = x, \quad (j+1)P_{j+1}(x) = (2j+1)xP_j(x) - jP_{j-1}(x),$$

Chebyshev 多项式满足

$$T_0(x) = 1, \quad T_1(x) = x, \quad T_{j+1}(x) = 2xT_j(x) - T_{j-1}(x).$$

这些递推生成的是相对于各自权重正交的方向, 而不是同一组多项式换了名称。

区间或权重改变后, 正交系数必须随之重算。把 $[a, b]$ 仿射映射到 $[-1, 1]$ 可以迁移 Legendre 或 Chebyshev 基, 但 Jacobian 因子和权重也会改变。Chebyshev 多项式还具有适合一致逼近与插值的极值分布; 这不意味着其加权 L^2 投影自动就是一致范数下的最佳逼近。投影结论始终相对于所选内积成立, 误差度量一旦改变, 最佳函数也可能改变。

4.3 正定核与再生核空间

4.3.1 连续线性泛函与 Riesz 表示

线性泛函是把空间元素映射为标量的线性映射。泛函 $L : \mathcal{H} \rightarrow \mathbb{R}$ 有界, 是指存在 $C < \infty$ 使 $|L(f)| \leq C\|f\|_{\mathcal{H}}$ 对所有 f 成立。在赋范空间上, 有界性与连续性等价。Hilbert 空间的内积给出一类直接的有界泛函: $L_h(f) = \langle f, h \rangle_{\mathcal{H}}$ 。Riesz 表示定理说明没有别的有界线性泛函¹。

定理 4.2 Riesz 表示定理 设 $\mathcal{H}$ 为实 Hilbert 空间。对每个有界线性泛函 $L : \mathcal{H} \rightarrow \mathbb{R}$, 存在唯一的 $h_L \in \mathcal{H}$, 使

$$L(f) = \langle f, h_L \rangle_{\mathcal{H}}, \quad f \in \mathcal{H}. \quad (4.7)$$

并且 $\|L\| = \|h_L\|_{\mathcal{H}}$, 其中 $\|L\| = \sup_{\|f\|_{\mathcal{H}} \leq 1} |L(f)|$ 。

证明. 若 $L = 0$, 取 $h_L = 0$ 即可。以下设 $L \neq 0$ 。核空间 $M = \ker L = \{f : L(f) = 0\}$ 是线性子空间; 由于 L 连续, M 也是闭集。选取 $u \in \mathcal{H}$ 使

¹ J. B. Conway, *A Course in Functional Analysis*, Springer, 1990, 2nd ed.

$L(u) \neq 0$ 。由定理 4.1, 可以把 u 唯一分解为

$$u = P_M u + v, \quad v \in M^\perp.$$

若 $v = 0$, 则 $u \in M$, 与 $L(u) \neq 0$ 矛盾, 故 $v \neq 0$ 。又因 $P_M u \in M = \ker L$,

$$L(v) = L(u) - L(P_M u) = L(u) \neq 0,$$

所以下面的除法合法。

对任意 $f \in \mathcal{H}$, 向量

$$f - \frac{L(f)}{L(v)} v$$

的 L 值为零, 因而属于 M 。它与 $v \in M^\perp$ 正交, 所以

$$0 = \left\langle f - \frac{L(f)}{L(v)} v, v \right\rangle_{\mathcal{H}} = \langle f, v \rangle_{\mathcal{H}} - \frac{L(f)}{L(v)} \|v\|_{\mathcal{H}}^2.$$

整理得到

$$L(f) = \left\langle f, \frac{L(v)}{\|v\|_{\mathcal{H}}^2} v \right\rangle_{\mathcal{H}}.$$

因此可取 $h_L = L(v)v/\|v\|_{\mathcal{H}}^2$ 。

若 h_1, h_2 都表示 L , 则 $\langle f, h_1 - h_2 \rangle = 0$ 对每个 f 成立。取 $f = h_1 - h_2$ 使得 $h_1 = h_2$ 。Cauchy-Schwarz 不等式给出 $|L(f)| \leq \|f\| \|h_L\|$, 所以 $\|L\| \leq \|h_L\|$; 当 $h_L \neq 0$ 时取 $f = h_L/\|h_L\|$ 得到反向不等式。 $h_L = 0$ 的情形也直接成立。 ■

4.3.2 有界点值泛函产生再生核

设 $\mathcal{H}$ 是定义在 $\mathcal{X}$ 上的实值函数 Hilbert 空间。对固定 $x \in \mathcal{X}$, 点值映射 $\delta_x(f) = f(x)$ 是线性的。如果每个 δ_x 都有界, Riesz 表示定理就给出唯一元素 $K_x \in \mathcal{H}$, 使

$$f(x) = \langle f, K_x \rangle_{\mathcal{H}}, \quad f \in \mathcal{H}. \quad (4.8)$$

这样的空间称为**再生核 Hilbert 空间**。定义

$$K(x, z) = K_z(x) = \langle K_z, K_x \rangle_{\mathcal{H}},$$

便得到空间的**再生核** (reproducing kernel)。式 (4.8) 说明“再生”的含义: 函数在 x 处的值可以由函数与核截面 $K_x = K(\cdot, x)$ 的内积读出。

普通 $L^2(\mu)$ 通常不是 RKHS。其元素是几乎处处等价类, 在单个点上改值不改变元素, 所以 $f(x)$ 甚至未必定义良好。即使人为选择代表元, 点值也一般不连续: 在 $[0, 1]$ 上可以构造支撑越来越窄而在固定点取值为 1 的连续尖峰, 其 L^2 范数趋于 0。因此, 从 L^2 收敛不能推出固定点的函数值

收敛。RKHS 范数额外控制点值，因为

$$|f(x)| \leq \|f\|_{\mathcal{H}} \|K_x\|_{\mathcal{H}} = \|f\|_{\mathcal{H}} \sqrt{K(x, x)}. \quad (4.9)$$

核 K 必为对称**正定核** (positive definite kernel): 对任意 $x_1, \dots, x_n \in \mathcal{X}$ 与 $a_1, \dots, a_n \in \mathbb{R}$,

$$\sum_{i,j=1}^n a_i a_j K(x_i, x_j) = \left\| \sum_{i=1}^n a_i K_{x_i} \right\|_{\mathcal{H}}^2 \geq 0. \quad (4.10)$$

这里沿用核理论的惯例, “正定”允许有限 Gram 矩阵奇异; 若非零系数和互异输入总使二次型严格为正, 才称严格正定。

正定核的一个可直接核验的来源是有限维特征内积。给定映射 $\phi: \mathcal{X} \rightarrow \mathbb{R}^d$, 令

$$K_\phi(x, z) = \langle \phi(x), \phi(z) \rangle_2.$$

对任意有限输入与实系数,

$$\sum_{i,j=1}^n a_i a_j K_\phi(x_i, x_j) = \left\| \sum_{i=1}^n a_i \phi(x_i) \right\|_2^2 \geq 0,$$

所以 K_ϕ 满足有限半正定条件。例如, 当 $\mathcal{X} \subseteq \mathbb{R}$ 且 $\phi(x) = (1, x)^\top$ 时, 得到 $K_\phi(x, z) = 1 + xz$ 。

4.3.3 从正定核反向构造空间

上面的推导从函数空间得到核。反方向同样成立, 而且不需要输入域带有拓扑或测度²。

定理 4.3 正定核的 RKHS 构造 设 $\mathcal{X}$ 为任意非空集合, $K: \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}$ 对称, 并满足式(4.10)的有限半正定条件。则存在唯一的函数 RKHS $\mathcal{H}_K$ 以 K 为再生核; 这里的唯一性指保持每个函数不变的等距同构。

证明. 先令 $\mathcal{V}_0$ 为核截面符号 K_x 的形式有限线性组合所成的向量空间:

$$\mathcal{V}_0 = \left\{ \sum_{i=1}^n a_i K_{x_i} : n \in \mathbb{N}, a_i \in \mathbb{R}, x_i \in \mathcal{X} \right\}.$$

这里的 K_x 暂时只是由 x 索引的形式符号, 尚未把不同形式和按逐点函数值识别。对 $f = \sum_i a_i K_{x_i}$ 和 $g = \sum_j b_j K_{z_j}$ 定义

$$\langle f, g \rangle_0 = \sum_{i,j} a_i b_j K(x_i, z_j). \quad (4.11)$$

² N. Aronszajn, *Theory of Reproducing Kernels* In Transactions of the American Mathematical Society, 1950, vol. 68, no. 3, pp. 337–404

正定性只保证 $\langle f, f \rangle_0 \geq 0$, 还可能有非零形式和的长度为零。令

$$\mathcal{N} = \{f \in \mathcal{V}_0 : \langle f, f \rangle_0 = 0\}.$$

由半内积的 Cauchy-Schwarz 不等式, $f \in \mathcal{N}$ 时 $\langle f, g \rangle_0 = 0$ 对所有 g 成立。因此可以商掉 $\mathcal{N}$, 使式 (4.11) 成为真正的内积。

还需证明这个商空间能够忠实地解释为函数。对形式和 $f = \sum_i a_i K_{x_i}$, 定义

$$(Jf)(x) = \sum_i a_i K(x, x_i) = \langle f, K_x \rangle_0.$$

若 $f \in \mathcal{N}$, 则

$$|(Jf)(x)|^2 = |\langle f, K_x \rangle_0|^2 \leq \langle f, f \rangle_0 K(x, x) = 0,$$

所以 Jf 处处为零。反过来, 若 Jf 处处为零, 则

$$\langle f, f \rangle_0 = \sum_i a_i (Jf)(x_i) = 0,$$

故 $f \in \mathcal{N}$ 。因此 $\ker J = \mathcal{N}$, 商空间 $\mathcal{H}_0 = \mathcal{V}_0 / \mathcal{N}$ 可单射地识别为函数空间, 并且其中的函数满足

$$f(x) = \langle f, K_x \rangle_0.$$

对这个内积空间作完备化, 得到 Hilbert 空间 $\mathcal{H}_K$ 。还要确认完备化后的抽象极限仍是函数。若 $(f_m) \subset \mathcal{H}_0$ 在核范数下为柯西序列, 则对每个 x ,

$$|f_m(x) - f_\ell(x)| \leq \|f_m - f_\ell\|_0 \sqrt{K(x, x)},$$

所以 $(f_m(x))$ 是实数柯西序列。定义 $f(x) = \lim_m f_m(x)$ 。若另一个柯西序列与 (f_m) 表示同一个完备化元素, 同一不等式保证两者逐点极限相同。故完备化元素具有良定义的函数值, 且内积连续性给出

$$f(x) = \lim_m \langle f_m, K_x \rangle_0 = \langle f, K_x \rangle_{\mathcal{H}_K}.$$

再生性质因此延伸到整个 $\mathcal{H}_K$ 。这个逐点解释在完备化后仍是单射: 若 $f \in \mathcal{H}_K$ 处处取零, 则 f 与每个 K_x 正交; 核截面的线性张成 $\mathcal{H}_0$ 在其完备化 $\mathcal{H}_K$ 中稠密, 所以 f 与整个空间正交, 只能有 $f = 0$ 。

唯一性也由这个构造确定。若另一个 RKHS $\widetilde{\mathcal{H}}$ 也以 K 为核, 则有限核截面和在两个空间中的内积都由式 (4.11) 决定。核截面的线性张成在任一空间中都稠密; 否则与所有 K_x 正交的函数 f 满足 $f(x) = 0$ 对所有 x 成立, 只能是零函数。所以有限核截面和之间的恒等映射唯一地延伸为两个完备空间之间的等距同构。 ■

定理4.3说明, 验证所有有限 Gram 矩阵半正定就足以定义一个 RKHS。它不同于 Mercer 谱展开。后者通常还假设 $\mathcal{X}$ 是紧空间、 K 连续, 并选定具有适当支持的有限测度; 这些条件使积分算子

$$(T_K f)(x) = \int_{\mathcal{X}} K(x, z) f(z) d\mu(z)$$

成为紧自伴算子, 从而可以用特征值与特征函数展开 K 。一般正定核即使不满足这些拓扑和测度条件, 仍有上述 RKHS 构造。因而, 核的合法性、核的谱展开以及谱展开的一致收敛是三项条件不同的结论。

4.3.4 表示定理把无限维求解降到有限张成空间

RKHS 可能无限维, 但许多训练目标只通过有限个点值读取 f 。再生性质使这些读取方向恰好由有限个核截面表示³。

定理 4.4 有限样本表示定理 设 $\mathcal{H}_K$ 是 $\mathcal{X}$ 上的 RKHS, 训练输入为 $x_1, \dots, x_n$ 。令 $\Phi: \mathbb{R}^n \rightarrow (-\infty, \infty]$ 为任意函数, $\Omega: [0, \infty) \rightarrow (-\infty, \infty]$ 单调不减。考虑

$$\inf_{f \in \mathcal{H}_K} \{ \Phi(f(x_1), \dots, f(x_n)) + \Omega(\|f\|_{\mathcal{H}_K}) \}. \quad (4.12)$$

若该问题存在最优解, 则至少有一个最优解具有形式

$$f^* = \sum_{i=1}^n a_i K_{x_i}. \quad (4.13)$$

若该问题的最优值有限且 Ω 严格递增, 则每个最优解都具有式 (4.13) 的形式。

³ B. Schölkopf, R. Herbrich, A. J. Smola, *A Generalized Representer Theorem In Computational Learning Theory*, 2001, pp. 416–426

证明. 记 $M = \text{span}\{K_{x_1}, \dots, K_{x_n}\}$ 。这是有限维子空间, 因而闭。由投影定理, 任意 $f \in \mathcal{H}_K$ 都可唯一分解为

$$f = f_M + f_{\perp}, \quad f_M \in M, \quad f_{\perp} \perp M.$$

对每个训练输入 x_i , 再生性质给出

$$f(x_i) = \langle f_M, K_{x_i} \rangle + \langle f_{\perp}, K_{x_i} \rangle = \langle f_M, K_{x_i} \rangle.$$

因此经验项 Φ 无法区分 f 与 f_M 。另一方面, 正交分解给出

$$\|f\|_{\mathcal{H}_K}^2 = \|f_M\|_{\mathcal{H}_K}^2 + \|f_{\perp}\|_{\mathcal{H}_K}^2,$$

故 $\|f_M\| \leq \|f\|$ 。当 Ω 单调不减时, 用 f_M 替换 f 不会增大目标值。若原问题存在最优解, 对任一最优解作此替换便得到 M 中的最优解, 也就是

式(4.13)。

若最优值有限、 Ω 严格递增且 $f_{\perp} \neq 0$ ，则 $\|f_M\| < \|f\|$ ，经验项不变而惩罚项严格减小，与 f 最优矛盾。这里最优目标值有限保证经验项与惩罚项都是有限值，因而惩罚项的严格下降确实使总目标严格下降。所以每个最优解都必须满足 $f_{\perp} = 0$ 。 ■

定理没有证明式(4.12)必定达到下确界。存在性仍要由目标的下半连续性、强制性、闭性或其他条件另行保证。它也没有保证系数向量 $(a_1, \dots, a_n)^T$ 唯一；若 Gram 矩阵奇异，不同系数可能表示同一个函数。单调不减惩罚只保证存在一个有限展开最优解；只有当最优值有限且惩罚严格递增时，才能排除每个最优解中的非零正交余项。若损失还依赖导数、积分或训练点之外的其他有界线性泛函，表示空间应加入这些泛函的 Riesz 表示元，不能仍机械地只写训练点核截面。

4.4 逼近能力与表示选择

4.4.1 稠密性只回答能否逼近

设 $\mathcal{F}$ 是赋范空间 $\mathcal{V}$ 的子集。若对每个 $f \in \mathcal{V}$ 和 $\varepsilon > 0$ ，都存在 $g \in \mathcal{F}$ 使 $\|f - g\|_{\mathcal{V}} < \varepsilon$ ，就称 $\mathcal{F}$ 在 $\mathcal{V}$ 中稠密。稠密性是一项表示存在性结论：它允许逼近器依赖目标和精度，却没有说明需要多少参数、怎样找到逼近器，或从有限观测能否识别它。

多项式提供一个基本例子。对 $f \in C([0, 1])$ ，定义 Bernstein 多项式

$$(B_m f)(x) = \sum_{j=0}^m f\left(\frac{j}{m}\right) \binom{m}{j} x^j (1-x)^{m-j}. \quad (4.14)$$

权重非负且由二项式定理知其和为 1，所以 $B_m f(x)$ 是邻近网格函数值的加权平均。

定理 4.5 Bernstein 逼近定理 对每个 $f \in C([0, 1])$,

$$\|B_m f - f\|_{\infty} \longrightarrow 0.$$

因此，多项式在 $C([0, 1])$ 的一致范数下稠密。

证明. 连续函数在紧区间上一致连续且有界。记 $M = \|f\|_{\infty}$ 。给定 $\varepsilon > 0$ ，可取 $\delta > 0$ 使 $|u - x| < \delta$ 时 $|f(u) - f(x)| < \varepsilon/2$ 。

对固定 x ，把式(4.14)中的权重记为 $w_{m,j}(x)$ 。除 $\sum_j w_{m,j}(x) = 1$ 外，直

接对二项式求导可得

$$\sum_{j=0}^m \left(\frac{j}{m} - x\right)^2 w_{m,j}(x) = \frac{x(1-x)}{m} \leq \frac{1}{4m}.$$

将网格点分为 $|j/m - x| < \delta$ 与 $|j/m - x| \geq \delta$ 两组。近处一组的函数值差小于 $\varepsilon/2$ 。远处一组的总权重满足

$$\sum_{|j/m - x| \geq \delta} w_{m,j}(x) \leq \frac{1}{\delta^2} \sum_{j=0}^m \left(\frac{j}{m} - x\right)^2 w_{m,j}(x) \leq \frac{1}{4m\delta^2}.$$

因此对所有 $x \in [0, 1]$,

$$|B_m f(x) - f(x)| \leq \frac{\varepsilon}{2} + 2M \frac{1}{4m\delta^2}.$$

取 m 足够大使第二项不超过 $\varepsilon/2$, 便得到一致误差不超过 ε 。界对所有 x 使用同一个 m , 所以结论是一致收敛。■

证明展示了规则性怎样影响逼近: 目标的一致连续性控制近处网格值的变化, 二项式权重的二阶离散矩控制远处权重。如果已知更强的光滑性, 可以得到更具体的误差速率; 只有连续性时, 定理仍给出存在性, 但不承诺对所有连续函数共享一个与目标无关的快速速率。

多项式同时调整全域系数, 分段线性样条则把改动限制在少数相邻区间。设 $a = x_0 < x_1 < \dots < x_m = b$, 最大网格宽度为 $h = \max_j (x_{j+1} - x_j)$, 并令 $S_h f$ 在结点处等于 f 、在每个小区间上线性插值。若 $\omega_f(h) = \sup_{|x-z| \leq h} |f(x) - f(z)|$ 是 f 的连续模, 则

$$\|f - S_h f\|_\infty \leq \omega_f(h).$$

这是因为区间内的插值值是两个端点函数值的凸组合, 每个端点距当前点都不超过 h 。当 f 二阶连续可微时, Taylor 余项进一步给出

$$\|f - S_h f\|_\infty \leq \frac{h^2}{8} \|f''\|_\infty.$$

前一个界只依赖连续性, 后一个界用更强规则性换取二阶误差。移动一个样条结点只改变相邻片段, 而改变一个全局多项式系数通常会影晌整个区间; 这是局部表示与全局表示的结构差别, 不是两种误差范数之间的优劣结论。

4.4.2 多项式、样条、核展开与神经网络改变不同结构

固定目标

$$f_\star(x) = \left|x - \frac{1}{2}\right|, \quad x \in [0, 1],$$

可以看清表示选择的差异。全局多项式用一组遍及整个区间的基函数逼近折点；分段线性样条只需把 $1/2$ 设为结点，就能精确表示 $f_\star$ 。使用宽度 $\sigma > 0$ 的高斯核

$$K_\sigma(x, z) = \exp\left(-\frac{(x - z)^2}{2\sigma^2}\right)$$

时，可以由若干局部核截面 $K_\sigma(\cdot, x_i)$ 组合出平滑逼近，但有限组合仍是光滑函数，不能在有限核宽度下精确产生折点。带 ReLU 激活的单隐藏层网络则可直接写成

$$f_\star(x) = \text{ReLU}\left(x - \frac{1}{2}\right) + \text{ReLU}\left(\frac{1}{2} - x\right).$$

这些差别来自表示与目标规则性的匹配，不能只由“哪一类更通用”判断。

为了把“适当激活函数”写成可核对的条件，称连续函数 $\sigma : \mathbb{R} \rightarrow \mathbb{R}$ 为**连续 S 形函数** (continuous sigmoidal function)，若

$$\lim_{t \rightarrow -\infty} \sigma(t) = 0, \quad \lim_{t \rightarrow +\infty} \sigma(t) = 1.$$

对紧立方体 $[0, 1]^d$ ，所有有限和

$$g(\mathbf{x}) = \sum_{i=1}^m a_i \sigma(\mathbf{w}_i^\top \mathbf{x} + b_i) \quad (4.15)$$

的并集在 $C([0, 1]^d)$ 的一致范数下稠密。也就是说，对每个连续目标和每个正误差，存在某个有限 m 及相应参数使一致误差达到要求。这里列述网络版本的普适逼近结论；本章对稠密性的完整构造证明由前面的 Bernstein 多项式承担⁴。

不同激活与误差空间还有其他普适逼近版本，但每个版本都必须重新写清定义域、目标集合和激活条件。它们共同的量词形式是

$$\forall f \forall \varepsilon > 0 \exists \text{网络规模与参数, 使误差小于 } \varepsilon.$$

这个陈述没有给出以下任何一项无条件保证：所需网络很小，参数能由可承受的计算找到，训练算法会到达该参数，或者有限样本上的拟合会在新输入上保持准确。多项式的稠密性也有同样边界。表示存在、参数规模、优化可计算性和统计泛化是四个不同问题。

误差范数同样决定结论。若只要求 L^2 误差小，逼近器可以在小测度区域出现较大尖峰；若要求一致误差小，则必须同时控制所有输入。若目标定义在非紧域上，还需要指定加权范数、局部一致收敛或尾部条件。若目标含不连续点，连续逼近器不可能在整个定义域上一致收敛到目标，却仍可能在 L^p 意义下逼近。讨论“普适”时必须同时写清目标集合、定义域、逼近器的并集和误差度量。

⁴ M. Leshno, V. Y. Lin, A. Pinkus, S. Schocken, *Multilayer Feedforward Networks with a Nonpolynomial Activation Function Can Approximate Any Function In Neural Networks*, 1993, vol. 6, no. 6, pp. 861–867

4.5 函数类的大小与平滑性

4.5.1 范数球把可选方向与幅度一起限制

稠密的表示族可能非常大。若允许多项式次数和系数任意增长，它既能逼近平滑趋势，也能产生快速振荡。实际分析通常固定一个半径 B ，考察范数球

$$\mathcal{F}_B = \{f \in \mathcal{V} : \|f\|_{\mathcal{V}} \leq B\}.$$

半径限制只有结合范数含义才有信息。 L^2 范数限制函数整体能量，却不直接限制导数；下一小节会先把导数定义为积分意义下的对象，再用 Sobolev 范数同时限制函数值与直到某个非负整数阶的导数，因而抑制快速振荡。Lipschitz 约束 $|f(x) - f(z)| \leq L|x - z|$ 则直接限制输入变化造成的输出变化。它们控制的对象不同，不能由一个较小的参数数量替代。

在 RKHS 中，式(4.9)说明核对角有界时，核范数球统一控制点值。两个输入之间还有

$$|f(x) - f(z)| \leq \|f\|_{\mathcal{H}_K} \|K_x - K_z\|_{\mathcal{H}_K}, \quad (4.16)$$

而

$$\|K_x - K_z\|_{\mathcal{H}_K}^2 = K(x, x) + K(z, z) - 2K(x, z).$$

因此，核既确定可用方向，也确定输入变化在空间中有多远；半径再限制沿这些方向的幅度。改变核与改变正则化强度不是同一操作。

4.5.2 弱导数把积分意义下的规则性纳入空间

经典导数要求逐点极限存在，会排除带尖点但整体仍然规则的函数。为了只保留积分运算真正需要的变化信息，设 $U \subseteq \mathbb{R}^d$ 为开集， $C_c^\infty(U)$ 表示在 U 内具有紧支撑的光滑测试函数。若 $f \in L_{\text{loc}}^1(U)$ ，取多重指标 $\alpha = (\alpha_1, \dots, \alpha_d) \in \mathbb{N}_0^d$ ，记 $|\alpha| = \sum_{j=1}^d \alpha_j$ ， $D^\alpha = \partial_1^{\alpha_1} \cdots \partial_d^{\alpha_d}$ 。若存在 $g_\alpha \in L_{\text{loc}}^1(U)$ 使每个 $\varphi \in C_c^\infty(U)$ 都满足

$$\int_U f(\mathbf{x}) D^\alpha \varphi(\mathbf{x}) d\mathbf{x} = (-1)^{|\alpha|} \int_U g_\alpha(\mathbf{x}) \varphi(\mathbf{x}) d\mathbf{x}, \quad (4.17)$$

就称 g_α 为 f 的 α 阶**弱导数** (weak derivative)，记为 $D^\alpha f$ 。式(4.17)把经典分部积分当作定义；测试函数的紧支撑使边界项消失，因此这个定义本身不需要给 U 另加边界条件。

对非负整数 m ，Sobolev 空间

$$W^{m,2}(U) = \{f \in L^2(U) : D^\alpha f \in L^2(U), |\alpha| \leq m\}$$

配备范数

$$\|f\|_{W^{m,2}(U)}^2 = \sum_{|\alpha| \leq m} \|D^\alpha f\|_{L^2(U)}^2. \quad (4.18)$$

当 $U = (a, b)$ 为一维区间时, $W^{m,2}(a, b)$ 也常记作 $H^m(a, b)$, 式 (4.18) 相应写成

$$\|f\|_{H^m(a,b)}^2 = \sum_{r=0}^m \int_a^b |D^r f(x)|^2 dx.$$

这里 $m \in \mathbb{N}_0$, 各阶导数都按上面的弱导数定义理解; 非整数阶 Sobolev 空间需要其他定义, 不由这个有限求和给出。例如一维函数 $f(x) = |x|$ 在原点没有经典导数, 但其一阶弱导数几乎处处等于 $\text{sign}(x)$; 在有界区间上, 它仍属于 $W^{1,2}$ 。尖点因而不会自动排除积分意义下的平滑性。

$W^{m,2}(U)$ 是 Hilbert 空间。证明完备性时, 取其中的柯西列 (f_n) 。对每个 $|\alpha| \leq m$, 序列 $(D^\alpha f_n)$ 在 $L^2(U)$ 中都是柯西列, 故收敛到某个 $g_\alpha \in L^2(U)$, 其中 g_0 记为 f 。把 f_n 的弱导数恒等式分别在两侧取极限; Cauchy-Schwarz 不等式保证与固定测试函数的积分连续, 于是

$$\int_U f D^\alpha \varphi = (-1)^{|\alpha|} \int_U g_\alpha \varphi.$$

因此 $g_\alpha = D^\alpha f$, 并且 $f_n \rightarrow f$ 于 $W^{m,2}(U)$ 。若另外要求零边界值或其他边界条件, 还须证明满足该条件的子空间闭; 一般 Sobolev 空间的完备性不能替这些边界条件作保证。

4.5.3 积分算子、谱衰减与有效维度

核的谱不是由某个有限 Gram 矩阵直接定义的。给定测度空间 $(\mathcal{X}, \mu)$ 和可测核 K , 先在 $L^2(\mu)$ 上定义积分算子

$$(T_K f)(x) = \int_{\mathcal{X}} K(x, z) f(z) d\mu(z). \quad (4.19)$$

线性算子 T 有界, 是指 $\|Tf\| \leq C\|f\|$; 若 $\langle Tf, g \rangle = \langle f, Tg \rangle$, 则称其自伴; 若 $\langle Tf, f \rangle \geq 0$, 则称其为正算子。紧算子还要求把任意有界序列映成具有收敛子列的序列, 这正是无限维中不能由有界性自动得到的性质。

若 $K \in L^2(\mu \otimes \mu)$, Cauchy-Schwarz 不等式给出 $\|T_K\|_{\text{op}} \leq \|K\|_{L^2(\mu \otimes \mu)}$, 且 T_K 是紧算子。后一个结论可由简单核逼近看出: 把 K 在 $L^2(\mu \otimes \mu)$ 中用有限个矩形指示函数的线性组合逼近, 相应积分算子只有有限维值域; 核的 L^2 逼近又控制算子范数误差, 所以 T_K 是有限秩算子的范数极限。对称核使 T_K 自伴, 核的有限半正定条件在积分有定义时使 T_K 为正算子。

紧自伴谱定理说明, T_K 的非零谱由有限重数的实特征值组成; 若非零特征值无限多, 它们只能聚集到 0。相应特征向量与零空间的闭线性张成等于整个 Hilbert 空间; 换言之, 一般元素由这些方向的正交级数在 Hilbert

范数下收敛得到。这个结论给出 $L^2(\mu)$ 中的算子谱，却还没有保证核本身在每个 (x, z) 处都等于特征函数级数⁵。

Mercer 定理补上点态展开所需的条件。设 $\mathcal{X}$ 为紧度量空间， μ 为有限、全支撑 Borel 测度， K 连续、对称并满足有限半正定条件；全支撑是指每个非空开集都有正测度。此时 T_K 的正特征值记为 (μ_j) ，相应 $L^2(\mu)$ 标准正交特征函数记为 (ψ_j) ，则

$$K(x, z) = \sum_{j \geq 1} \mu_j \psi_j(x) \psi_j(z),$$

且级数在 $\mathcal{X} \times \mathcal{X}$ 上绝对、一致收敛。紧自伴谱定理、Mercer 点态展开和有限 Gram 矩阵的特征分解因而是三个层次的结论；缺少连续性、紧定义域或全支撑测度时，不能把最后一个结论直接外推为前两个结论⁶。

在上述 Mercer 条件下， $\mu_j > 0$ 的方向构成相应 RKHS 的谱坐标。函数可写成 $f = \sum_j b_j \psi_j$ ，其范数为

$$\|f\|_{\mathcal{H}_K}^2 = \sum_{j: \mu_j > 0} \frac{b_j^2}{\mu_j}. \quad (4.20)$$

小特征值方向受到更强惩罚。若 μ_j 迅速衰减，固定半径的函数难以在高编号方向上拥有大系数；若谱衰减缓慢，则更多方向能够自由变化。

谱表达还能直接展示二次正则化怎样收缩不同方向。设目标 $y = \sum_{j: \mu_j > 0} c_j \psi_j$ 位于正特征方向的闭张成空间，考虑

$$\min_{f \in \mathcal{H}_K} \left\{ \|f - y\|_{L^2(\mu)}^2 + \lambda \|f\|_{\mathcal{H}_K}^2 \right\}, \quad \lambda > 0.$$

写 $f = \sum_j b_j \psi_j$ 后，各方向彼此分离，最优系数为

$$b_j^* = \frac{\mu_j}{\mu_j + \lambda} c_j. \quad (4.21)$$

特征值远小于 λ 的方向被强烈收缩，特征值远大于 λ 的方向则大体保留。这与第3章的二次正则化是同一逐方向机制；定理 4.4 的有限表示处理训练点目标，这里的谱解则处理总体 $L^2(\mu)$ 目标，两者不能省略各自的存在条件而互相替代。

给定正则化尺度 $\lambda > 0$ ，常用

$$d_{\text{eff}}(\lambda) = \sum_{j \geq 1} \frac{\mu_j}{\mu_j + \lambda} \quad (4.22)$$

描述**有效维度** (effective dimension)；这个定义要求右侧级数有限，等价

⁵ J. B. Conway, *A Course in Functional Analysis*, Springer, 1990, 2nd ed.

⁶ J. Mercer, *Functions of Positive and Negative Type, and Their Connection with the Theory of Integral Equations* In Philosophical Transactions of the Royal Society of London, Series A, 1909, vol. 209, pp. 415–446

地可写成

$$d_{\text{eff}}(\lambda) = \text{tr}(T_K(T_K + \lambda I)^{-1})$$

并要求该算子为**迹类算子** (trace-class operator)。白话地说, 迹类表示无限维算子仍有有限的“谱总量”; 严格地说, 它的奇异值之和有限。对这里的正算子, 这等价于非负特征值之和有限, 迹就是这个和。因此 $T_K(T_K + \lambda I)^{-1}$ 为迹类, 恰好表示式 (4.22) 中的级数有限。每个谱方向按其相对于 λ 的大小贡献 0 到 1 之间的量。 $\mu_j \gg \lambda$ 的方向近似贡献 1, $\mu_j \ll \lambda$ 的方向贡献很小。有限样本 Gram 矩阵也有对应量

$$\text{tr}(\mathbf{K}(\mathbf{K} + n\lambda \mathbf{I}_n)^{-1}),$$

但它依赖当前输入与归一化约定, 不应和总体积分算子的 $d_{\text{eff}}(\lambda)$ 混为同一数值。

有效维度不是代数维数。无限维空间在固定 λ 下可以有有限有效维度; 反过来, 一个有限参数化若参数到函数的映射高度敏感, 也可能形成很大的函数集合。参数数量、谱衰减、导数规则性和范数半径从不同方面描述复杂度。后续核正则化会同时使用谱和范数; 神经切线核只在相应线性化条件下提供这种空间解释, 深层网络本身的复杂度不能无条件等同于某个固定核的有效维度。

4.6 函数类的组合与度量复杂度

4.6.1 有限输入上的取值模式

设 $\mathcal{F} \subseteq \{0, 1\}^{\mathcal{X}}$ 是二值函数类。给定输入 $S = (x_1, \dots, x_n)$, 函数类在 S 上的限制为

$$\mathcal{F}|_S = \{(f(x_1), \dots, f(x_n)) : f \in \mathcal{F}\}.$$

增长函数 (growth function)

$$\Pi_{\mathcal{F}}(n) = \sup_{x_1, \dots, x_n \in \mathcal{X}} \#(\mathcal{F}|_S) \quad (4.23)$$

记录 n 个输入上最多能产生多少种二值模式。若 $\Pi_{\mathcal{F}}(n) = 2^n$, 就称某组 n 个点被 $\mathcal{F}$ 打散。能够打散的最大点数称为 VC 维; 若任意大的有限点集都能被打散, 则 VC 维为无穷。

增长函数不要求输入来自某个随机分布, 它描述纯粹的组合丰富度。例如实线上的阈值函数 $f_a(x) = \mathbb{I}\{x \geq a\}$ 在 n 个互异且有序的输入上只能产生 $n+1$ 种模式, 而全部二值函数可以产生 2^n 种模式。参数 a 虽然是一个实数, 组合模式却由输入次序强烈限制; 参数空间连续不等于每个有限集合上都能任意标记。

有限函数类给出另一个直接的上界。若 $\#\mathcal{F} = M < \infty$ ，每个函数在固定输入组上至多贡献一种模式，因而

$$\Pi_{\mathcal{F}}(n) \leq \min\{M, 2^n\}.$$

例如只含两个常值函数 $f_0(x) = 0$ 与 $f_1(x) = 1$ 的函数类，在任意非空输入组上恰好产生全零和全一两种模式，所以 $\Pi_{\mathcal{F}}(n) = 2$ 对所有 $n \geq 1$ 成立。有限类的函数数目限制了模式总数，但不同函数在某组输入上可能给出相同限制，因此一般只能得到上界。

对实值函数，仅记录正负号会丢掉幅度与尺度。给定 $\gamma > 0$ ，若存在输入 $x_1, \dots, x_n$ 和阈值 $r_1, \dots, r_n$ ，使每个符号向量 $\sigma \in \{-1, 1\}^n$ 都对应某个 $f_{\sigma} \in \mathcal{F}$ 满足

$$\sigma_i(f_{\sigma}(x_i) - r_i) \geq \gamma, \quad i = 1, \dots, n, \quad (4.24)$$

则称这些点在尺度 γ 下被胖打散。最大点数称为尺度 γ 下的**胖打散维** (fat-shattering dimension)。 γ 越大，要求的间隔越宽，能够实现的模式通常越少。这个定义把“能否改变符号”和“能否以可分辨幅度改变数值”区分开来。

幅度约束怎样进入这个维数，可以由简单函数直接算出。设非空集合 $A_1, \dots, A_m$ 构成 X 的一个划分，并令

$$\mathcal{F}_B = \left\{ \sum_{j=1}^m a_j \mathbb{I}_{A_j} : |a_j| \leq B \right\}, \quad B > 0.$$

当 $0 < \gamma \leq B$ 时，从每个 A_j 选一点并取阈值 $r_j = 0$ ；对任意符号模式令 $a_j = \gamma \sigma_j$ ，便能以间隔 γ 实现该模式，所以这 m 个点被胖打散。反过来，任意 $m+1$ 个点中至少两个落在同一个 A_j 内，而类中每个函数在这两个点取值相同。若二者的阈值为 r 与 r' 且能够被胖打散，模式 $(+1, -1)$ 要求 $r' - r \geq 2\gamma$ ，模式 $(-1, +1)$ 又要求 $r - r' \geq 2\gamma$ ，二者矛盾。因此该尺度下的胖打散维恰为 m 。当 $\gamma > B$ 时，单点上的两个符号也要求函数值之差至少为 2γ ，超过允许区间 $[-B, B]$ 的宽度 $2B$ ，故胖打散维为 0。这个算例把分区数控制的自由方向与系数上界控制的可分辨幅度分开了。

4.6.2 覆盖数依赖距离与尺度

组合模式适合离散输出，连续函数还可以通过度量覆盖。设 $(\mathcal{F}, d)$ 为伪度量空间。若有限集合 $\mathcal{C} \subseteq \mathcal{F}$ 满足：对每个 $f \in \mathcal{F}$ ，存在 $g \in \mathcal{C}$ 使 $d(f, g) \leq \varepsilon$ ，则 $\mathcal{C}$ 称为 ε -覆盖。最小覆盖大小记为

$$N(\varepsilon, \mathcal{F}, d),$$

其对数称为度量熵。覆盖数回答的是：在指定误差尺度下，需要多少个代表函数才能近似整个函数类。它不是函数类元素个数；无穷函数类在正尺度下仍可能有有限覆盖。

距离的选择会改变覆盖对象。常见形式包括

$$\begin{aligned} d_\infty(f, g) &= \sup_{x \in \mathcal{X}} |f(x) - g(x)|, \\ d_{L^2(\mu)}(f, g) &= \left(\int_{\mathcal{X}} |f(x) - g(x)|^2 d\mu(x) \right)^{1/2}, \\ d_S(f, g) &= \left(\frac{1}{n} \sum_{i=1}^n |f(x_i) - g(x_i)|^2 \right)^{1/2}. \end{aligned}$$

d_∞ 同时控制所有输入， $d_{L^2(\mu)}$ 只控制测度 μ 加权的整体差异， d_S 只看给定有限输入。一个样本距离下很小的覆盖未必控制样本外的函数差异；一个 $L^2(\mu)$ 覆盖也未必控制 μ 几乎不赋质量的区域。后续概率论章建立随机样本后，才会讨论怎样把这些确定性覆盖结构接到同时误差概率界。

有限输入上的量化给出一个可以直接核对的覆盖。设每个 $f \in \mathcal{F}$ 在 $S = (x_1, \dots, x_n)$ 上都取值于 $[-B, B]$ 。把该区间分成长度不超过 ε 的小区间，并对每个被 $\mathcal{F}|_S$ 占据的 n 维网格单元选取一个代表函数。落在同一单元的两个函数在每个 x_i 处相差不超过 ε ，因而其 d_S 距离也不超过 ε 。由此得到

$$N(\varepsilon, \mathcal{F}, d_S) \leq \left(1 + \left\lceil \frac{2B}{\varepsilon} \right\rceil \right)^n.$$

这个界同时写出了值域 $[-B, B]$ 、分辨率 ε 和输入数 n 。它只覆盖 S 上可见的取值向量，不控制其他输入，也不声称该上界达到最小覆盖大小。

覆盖结构还可以由函数类运算传播。若 $\mathcal{F}$ 与 $\mathcal{G}$ 在同一上确界距离下分别有 ε_F 与 ε_G 覆盖，则

$$\mathcal{F} + \mathcal{G} = \{f + g : f \in \mathcal{F}, g \in \mathcal{G}\}$$

有半径 $\varepsilon_F + \varepsilon_G$ 、大小至多为两个覆盖大小乘积的覆盖。若 $\varphi : \mathbb{R} \rightarrow \mathbb{R}$ 是 L -Lipschitz 函数，则把 $\mathcal{F}$ 的 ε -覆盖逐点送入 φ ，得到 $\varphi \circ \mathcal{F}$ 的 $L\varepsilon$ -覆盖。这些关系说明组合结构怎样累积复杂度，却不自动给出有限样本泛化结论。

多分类函数类还需要记录多个类别之间可实现的标记关系。Natarajan 维、图维和 DS 维采用不同的组合对象；它们的专门可学习性结论留在机器学习理论部分。本章保留的共同原则是：先规定在哪些输入、以什么输出区分和误差尺度比较函数，再谈函数类“大小”。脱离这些对象，单独说某个函数类复杂或简单没有确定含义。

4.7 序贯函数类与低秩分解

4.7.1 查询树表示输入可以依赖过去

前一节把输入 $x_1, \dots, x_n$ 预先固定。序贯问题允许第 t 个输入根据此前反馈变化，单个输入序列因而不能列出所有可能路径。这里用二叉树表达分支，并以 $\epsilon_t \in \{-1, 1\}$ 标记第 t 步选择的分支； ϵ_t 只是抽象路径标签，不必等于实值函数输出 $f(x_t)$ 。若具体问题的反馈不是二元值，还需另行给出编码规则或改用相应的分支集合。深度为 T 的**查询树** (query tree) 用映射

$$x_t : \{-1, 1\}^{t-1} \rightarrow \mathcal{X}, \quad t = 1, \dots, T,$$

表示这种依赖。根节点输入为 x_1 ；在路径 $\epsilon = (\epsilon_1, \dots, \epsilon_T)$ 上，第 t 步访问 $x_t(\epsilon_1, \dots, \epsilon_{t-1})$ 。同一个函数 f 沿该路径产生

$$(f(x_1), f(x_2(\epsilon_1)), \dots, f(x_T(\epsilon_1, \dots, \epsilon_{T-1}))).$$

树的作用不是给函数增加随机性，而是同时编码所有按过去分支的输入选择规则。

在一棵固定查询树上，函数树 $v = (v_t)$ 可为每个节点指定一个实数。若对每个 $f \in \mathcal{F}$ 和每条路径 ϵ ，都存在覆盖元素 v 使

$$\left(\frac{1}{T} \sum_{t=1}^T |f(x_t(\epsilon_{1:t-1})) - v_t(\epsilon_{1:t-1})|^2 \right)^{1/2} \leq \epsilon, \quad (4.25)$$

就得到该树上的序贯 ϵ -覆盖。覆盖集合必须在选择具体函数与路径之前固定，其中每个 v 都为整棵树的节点赋值，并且第 t 层的值只依赖此前分支 $\epsilon_{1:t-1}$ 。针对不同的 f 与路径可以从该固定集合中选择不同 v ；不能做的是在看到完整未来后临时构造一个不属于预定覆盖集合的数值序列。正是这种树形、非前视的中心保留了序贯信息约束。

序贯覆盖数对所有深度 T 查询树取最坏情形。它通常不小于固定输入覆盖，因为不分支的树是特殊情形。反向大小需要函数类的额外规则性，不能仅凭定义得到。与胖打散维相似，还可以定义带间隔的序贯打散维；它衡量函数类能否沿树的每条分支持续作出可分辨选择。概率界、在线遗憾或自适应采样保证还需要后续章节的随机与算法条件，这里只建立输入可适应变化时应使用的结构对象。

深度为 2 的树已经能展示固定覆盖与序贯覆盖的差别。设根节点查询 x_0 ；沿标签 $\epsilon_1 = -1$ 的分支查询 x_- ，沿标签 $\epsilon_1 = 1$ 的分支查询 x_+ ，并假设函数在这三个点上的值都属于 $[-B, B]$ 。把三个节点值分别量化到宽度不超过 ϵ 的区间，并为每个被函数类占据的三维网格单元保留一棵代表函数树，就得到序贯 ϵ -覆盖：左路径比较 (x_0, x_-) 上的两个值，右路径比较

(x_0, x_+) 上的两个值, 每条路径的平方平均误差都不超过 ε 。固定两点覆盖只需描述一条已经选定的路径; 树覆盖必须在分支发生前同时准备 x_- 与 x_+ 处的值。因此, 不能等路径进入某个分支后, 再用一个未属于预定覆盖集合的新近似器补上所选分支。

4.7.2 低秩把两类索引之间的变化分解为少数方向

另一类结构来自双索引量。设 $p \in \mathcal{P}$ 表示一种预测或模型索引, $q \in \mathcal{Q}$ 表示一种查询、条件或检验索引, 量 $E(p, q) \in \mathbb{R}$ 记录二者组合后的函数值或误差。选取有限对象 $p_1, \dots, p_m$ 与 $q_1, \dots, q_n$, 可组成矩阵

$$E_{i,j} = E(p_i, q_j).$$

若存在映射 $\mathbf{u} : \mathcal{P} \rightarrow \mathbb{R}^r$ 与 $\mathbf{v} : \mathcal{Q} \rightarrow \mathbb{R}^r$ 使

$$E(p, q) = \langle \mathbf{u}(p), \mathbf{v}(q) \rangle, \quad (4.26)$$

则任意有限矩阵 E 的秩至多为 r 。低秩的含义是所有双索引变化都可由 r 个潜在方向组合, 而不是矩阵元素数目少。

Cauchy-Schwarz 不等式还把因子尺度传到每个矩阵元素:

$$|E(p, q)| \leq \|\mathbf{u}(p)\|_2 \|\mathbf{v}(q)\|_2.$$

所以秩控制可用方向数, 因子范数控制沿这些方向能够产生的幅度。

秩本身只计方向数, 不控制数值尺度。若把因子同时变换为 $\mathbf{u}'(p) = c\mathbf{u}(p)$ 和 $\mathbf{v}'(q) = \mathbf{v}(q)/c$, 式 (4.26) 不变, 单边因子范数却可以任意改变。因此, 用低秩结构控制误差或计算时, 通常还要固定

$$\sup_{p \in \mathcal{P}} \|\mathbf{u}(p)\|_2 \leq B_u, \quad \sup_{q \in \mathcal{Q}} \|\mathbf{v}(q)\|_2 \leq B_v,$$

或采用对这种缩放更稳定的矩阵范数。方向数 r 与幅度 $B_u B_v$ 承担不同作用。

严格低秩也可能过强。若存在

$$E(p, q) = \langle \mathbf{u}(p), \mathbf{v}(q) \rangle + \eta(p, q), \quad \sup_{p, q} |\eta(p, q)| \leq \delta,$$

则 r 描述结构化主项的方向数, δ 描述剩余表示误差。增大 r 可能减小 δ , 但不会自动给出怎样找到因子、怎样选择查询或怎样由有限观测估计矩阵。代数上的低秩、因子范数、逼近误差、数据访问条件和计算过程仍须分别说明。

强化学习中的某些复杂度概念会把模型与分布之间的 Bellman 残差组

织成类似矩阵，再研究其秩或因子化结构。那里的矩阵条目、可实现性、查询协议和样本保证依赖具体决策对象，必须在相应章节重新定义。仅仅看到某个双线性表达，既不能直接称其为 Bellman 秩，也不能推出高效学习。本节提供的是识别这类结构时所需的共同语言。

4.8 本章小结

当候选对象从固定长度的系数向量扩展为函数时，必须先说明怎样比较函数。Banach 空间用完备范数容纳逼近极限，Hilbert 空间再用内积建立正交与投影。闭凸集投影定理中，凸性与内积几何先使最小化序列成为柯西列，空间完备性给出极限，集合闭性让极限仍然可行；凸性还保证最近点唯一。闭子空间上的残差正交由此推广有限维最小二乘。正交系的完备性则是另一件事，它要求所选方向稠密张成整个空间，不能与 Hilbert 空间容纳柯西极限的完备性混用。

点值读取不是任意函数空间自动具备的操作。点值泛函有界时，Riesz 表示把它变成与核截面的内积，从而得到 RKHS；反过来，任意正定核都能通过有限核截面、零范数商空间与完备化构造唯一的 RKHS。表示定理随后说明，只依赖有限训练点值并配合单调范数惩罚的优化问题，只要最优解存在，就可在有限核截面张成空间中找到最优解。存在性、系数唯一性和 Mercer 谱展开仍各有额外条件，不能由表示形式代替。

函数能够被任意精度逼近，只回答表示存在性。所需规模、求解过程和有限观测下的误差是另外的问题。范数与平滑性限制函数变化的幅度，谱和有效维度刻画在给定尺度下仍活跃的方向，增长函数、胖打散维与覆盖数则从取值模式或度量分辨率描述函数类大小。输入可以根据过去变化时，需要用查询树上的序贯结构；双索引关系可由低秩与因子范数描述，但还须单独保留逼近误差和访问条件。第 5 章将先回到有限维空间，系统建立坐标、投影、范数与低秩表示；后续第 8 章再把平方可积函数的预测重新解释为条件期望投影，并把这些确定性函数类结构接到有限观测的同时误差控制。

第二部分

线性代数与几何

Linear Algebra and Geometry

线性代数

第 1 部分已经多次使用向量和矩阵：参数写成向量，导数给出局部线性近似，最小二乘把一组预测与观测作比较。但同一串数字有时表示空间中的对象，有时只是对象在某组基下的坐标；同一个线性映射换一组坐标后会得到不同的矩阵；两个特征几乎重复时，预测结果可能变化不大，表示它的系数却会剧烈变化。若不区分这些层次，公式虽然能够相乘，所得结论却未必对应原来的问题。

本章用一组近共线特征贯穿这些区别。令

$$\mathbf{X}_\varepsilon = \begin{bmatrix} 1 & 1 \\ 1 & 1 + \varepsilon \\ 1 & 1 - \varepsilon \end{bmatrix} = [\mathbf{c}_1 \quad \mathbf{c}_2], \quad \mathbf{q} = \begin{bmatrix} 0 \\ 1 \\ -1 \end{bmatrix}, \quad (5.1)$$

其中 $\mathbf{c}_1 = (1, 1, 1)^\top$ 且 $\mathbf{c}_2 = \mathbf{c}_1 + \varepsilon \mathbf{q}$ 。当 $\varepsilon \neq 0$ 时，两列线性无关；当 $\varepsilon = 0$ 时，它们完全重合。只要 $|\varepsilon|$ 很小，两列的夹角便很小，因而称为**近共线** (nearly collinear)。这不是说样本点彼此接近，而是说作为 $\mathbb{R}^3$ 中向量的两列特征接近同一个方向。

我们将先分开抽象向量与坐标，再把线性作用写成矩阵，随后用范数和内积说明“接近”采用了什么尺度。投影与最小二乘把这些结构用于拟合，多维数组与缩并则把同样的线性运算扩展到带有多个索引的表示。第 5 章只建立这些关系；不同方向被线性映射放大多少、近共线为何造成数值敏感，以及伪逆如何选择秩不足问题中的系数，将由下一章的谱与奇异值工具继续回答。

5.1 向量空间与坐标

5.1.1 向量空间规定哪些运算仍留在空间中

向量不必天然是一列数字。位移、有序信号、函数和矩阵都可以相加，也可以乘一个标量；只要这些运算满足共同规则，就能作为同一种代数对象处理。设 F 表示标量域，本书主要使用实数域 $\mathbb{R}$ ，涉及频率表示时也会使

用复数域 $\mathbb{C}$ 。**向量空间** (vector space) V 是一个集合, 其上定义了向量加法与标量乘法, 并且对任意 $\mathbf{u}, \mathbf{v}, \mathbf{w} \in V$ 和 $a, b \in \mathbb{F}$ 满足

$$\mathbf{u} + \mathbf{v} \in V, \quad a\mathbf{u} \in V,$$

以及加法的结合律和交换律、零向量与加法逆元的存在、标量乘法的结合律和分配律, 并有 $1\mathbf{v} = \mathbf{v}$ 。这些条件的作用是保证有限次线性运算不会离开 V 。

例如, $\mathbb{R}^d$ 在逐坐标加法和数乘下是实向量空间; 所有 $m \times d$ 实矩阵组成的集合 $\mathbb{R}^{m \times d}$ 也是实向量空间。次数不超过 k 的实系数多项式同样构成向量空间, 因为两个这类多项式相加或数乘后, 次数仍不超过 k 。相比之下,

$$H = \{\mathbf{x} \in \mathbb{R}^d : x_1 = 1\}$$

不是通常运算下的向量空间: 它不包含零向量, 而且两个元素相加后的第一坐标为 2。集合是否“看起来像一条直线或一个平面”并非判断标准, 封闭性与向量空间公理才是。

若 $U \subseteq V$ 在 V 的加法和数乘下本身构成向量空间, 就称 U 为 V 的**线性子空间** (linear subspace)。验证非空集合 U 为子空间时, 可以合并检查为

$$\forall \mathbf{u}, \mathbf{v} \in U, \forall a, b \in \mathbb{F}, \quad a\mathbf{u} + b\mathbf{v} \in U.$$

取 $a = b = 0$ 可见零向量必须在 U 中。因而不过原点的仿射直线不是线性子空间, 即使它仍能用少量坐标描述。

5.1.2 张成与线性无关分别回答覆盖和冗余

给定 $\mathbf{v}_1, \dots, \mathbf{v}_k \in V$, 形如

$$a_1\mathbf{v}_1 + \dots + a_k\mathbf{v}_k, \quad a_1, \dots, a_k \in \mathbb{F},$$

的向量称为它们的**线性组合** (linear combination)。所有线性组合组成的集合

$$\text{span}\{\mathbf{v}_1, \dots, \mathbf{v}_k\} = \left\{ \sum_{j=1}^k a_j \mathbf{v}_j : a_j \in \mathbb{F} \right\}$$

是包含这些向量的最小线性子空间, 称为它们的**张成空间** (span)。“能否表示目标对象”由目标是否属于张成空间决定。

覆盖空间并不意味着表示唯一。若

$$a_1\mathbf{v}_1 + \dots + a_k\mathbf{v}_k = \mathbf{0} \tag{5.2}$$

只在 $a_1 = \cdots = a_k = 0$ 时成立, 就称这组向量**线性无关** (linearly independent)。否则, 其中至少一个非零系数参与了式(5.2); 选取一个非零的 a_j 并移项, 便能把 $\mathbf{v}_j$ 写成其余向量的线性组合。线性相关因此准确表达了表示中的冗余, 而不只是两个向量恰好相等。

式(5.1)给出了一个可以直接核对的例子。若

$$a_1 \mathbf{c}_1 + a_2 \mathbf{c}_2 = (a_1 + a_2) \mathbf{c}_1 + a_2 \varepsilon \mathbf{q} = \mathbf{0},$$

由于 $\mathbf{c}_1$ 的三个坐标相同, 而 $\mathbf{q}$ 的后两个坐标符号相反, $\mathbf{c}_1$ 与 $\mathbf{q}$ 线性无关。当 $\varepsilon \neq 0$ 时, 只能有 $a_2 = 0$ 和 $a_1 = 0$, 所以 $\mathbf{c}_1, \mathbf{c}_2$ 线性无关。当 $\varepsilon = 0$ 时, $\mathbf{c}_2 = \mathbf{c}_1$, 取 $(a_1, a_2) = (1, -1)$ 便得到非平凡关系。近共线与线性相关不是一回事: 前者描述接近退化的程度, 后者是一个精确的是非判断。

5.1.3 基把对象变成坐标

向量空间 V 的一组向量若既线性无关又张成 V , 就称为 V 的一组**基**(basis)。设 $\mathcal{B} = (\mathbf{b}_1, \dots, \mathbf{b}_d)$ 是一组有序基。每个 $\mathbf{v} \in V$ 都能唯一写成

$$\mathbf{v} = x_1 \mathbf{b}_1 + \cdots + x_d \mathbf{b}_d.$$

系数组成的列向量

$$[\mathbf{v}]_{\mathcal{B}} = (x_1, \dots, x_d)^{\top} \in \mathbb{F}^d$$

称为 $\mathbf{v}$ 在基 $\mathcal{B}$ 下的**坐标** (coordinates)。存在性来自基的张成性质; 若有两组坐标, 相减后得到式(5.2)形式的关系, 线性无关性又保证两组系数相同。

一组基所含向量的个数称为有限维空间的**维数** (dimension), 记作 $\dim V$ 。同一有限维空间的任意两组基所含向量数相同, 因此维数不依赖具体坐标选择。 $\mathbb{R}^d$ 的标准基是 $\mathbf{e}_1, \dots, \mathbf{e}_d$, 其中 $\mathbf{e}_j$ 只有第 j 个坐标为 1。平常把向量直接写成数字列, 实际是在默认使用这组标准基。

若 V 能由有限个向量张成, 就可以从一组有限生成向量中反复删除可由其余向量表示的成员, 直至得到一组基。因此每个有限维向量空间都有基。更一般地, V 中的任意线性无关组都能通过加入向量扩充为一组基; 这也说明后文从子空间的基扩充到整个空间的基是合法的。第4章式(4.1)中的基函数展开正是同一坐标关系: 函数是向量空间中的对象, 系数列是它在所选函数基下的坐标。

对象与坐标的区别在近共线例子中尤其重要。固定 $\delta = 0.1$ 并令

$$\mathbf{y} = \mathbf{c}_1 + \delta \mathbf{q} = \begin{bmatrix} 1 \\ 1.1 \\ 0.9 \end{bmatrix}. \quad (5.3)$$

在基 $\mathcal{B}_0 = (\mathbf{c}_1, \mathbf{q})$ 下, $[\mathbf{y}]_{\mathcal{B}_0} = (1, \delta)^\top$ 。若 $\varepsilon \neq 0$, 同一个子空间也可用 $\mathcal{B}_\varepsilon = (\mathbf{c}_1, \mathbf{c}_2)$ 作为基。由 $\mathbf{q} = (\mathbf{c}_2 - \mathbf{c}_1)/\varepsilon$ 可得

$$\mathbf{y} = \left(1 - \frac{\delta}{\varepsilon}\right) \mathbf{c}_1 + \frac{\delta}{\varepsilon} \mathbf{c}_2. \quad (5.4)$$

当 $\varepsilon = 0.01$ 时, 坐标从 $(1, 0.1)^\top$ 变成 $(-9, 10)^\top$, 但空间中的对象 $\mathbf{y}$ 没有改变。大系数在这里首先反映所选基接近线性相关, 不能单凭坐标绝对值断言对象本身很大。

5.1.4 换基改变表示, 不改变线性关系

设 $\mathcal{B} = (\mathbf{b}_1, \dots, \mathbf{b}_d)$ 与 $\mathcal{C} = (\mathbf{c}_1, \dots, \mathbf{c}_d)$ 都是 V 的基。把每个 $\mathbf{b}_j$ 在 $\mathcal{C}$ 下的坐标作为第 j 列, 得到换基矩阵

$$\mathbf{S}_{\mathcal{C} \leftarrow \mathcal{B}} = \begin{bmatrix} [\mathbf{b}_1]_{\mathcal{C}} & \cdots & [\mathbf{b}_d]_{\mathcal{C}} \end{bmatrix}.$$

由于坐标映射保持线性组合,

$$[\mathbf{v}]_{\mathcal{C}} = \mathbf{S}_{\mathcal{C} \leftarrow \mathcal{B}} [\mathbf{v}]_{\mathcal{B}}. \quad (5.5)$$

两组基都能唯一表示对象, 所以换基矩阵可逆, 其逆是 $\mathbf{S}_{\mathcal{B} \leftarrow \mathcal{C}}$ 。

在 $\mathcal{B}_0 = (\mathbf{c}_1, \mathbf{q})$ 与 $\mathcal{B}_\varepsilon = (\mathbf{c}_1, \mathbf{c}_2)$ 之间,

$$\mathbf{S}_{\mathcal{B}_0 \leftarrow \mathcal{B}_\varepsilon} = \begin{bmatrix} 1 & 1 \\ 0 & \varepsilon \end{bmatrix}.$$

它的行列式为 ε , 在 $\varepsilon \neq 0$ 时可逆; 随着 ε 趋近 0, 逆矩阵中的 $1/\varepsilon$ 项增大。这一计算已经揭示坐标敏感性的来源, 但要定量比较不同方向上的放大, 还需要下一章的奇异值与条件数。

5.2 矩阵与线性映射

5.2.1 矩阵是线性映射在给定基下的表示

设 V, W 是同一标量域上的向量空间。映射 $T: V \rightarrow W$ 若对任意 $\mathbf{u}, \mathbf{v} \in V$ 和 $a, b \in \mathbb{F}$ 满足

$$T(a\mathbf{u} + b\mathbf{v}) = aT(\mathbf{u}) + bT(\mathbf{v}),$$

就称为**线性映射** (linear map)。它保留线性组合, 特别有 $T(\mathbf{0}) = \mathbf{0}$ 。带有非零偏置的映射 $\mathbf{x} \mapsto \mathbf{Ax} + \mathbf{b}$ 通常称为仿射映射; 只有 $\mathbf{b} = \mathbf{0}$ 时才是线性映射。

给定 V 的基 $\mathcal{B} = (\mathbf{b}_1, \dots, \mathbf{b}_d)$ 和 W 的基 $\mathcal{C} = (\mathbf{c}_1, \dots, \mathbf{c}_m)$, 线性映射完全由各基向量的像决定。把 $[T(\mathbf{b}_j)]_{\mathcal{C}}$ 作为第 j 列, 得到矩阵 $[T]_{\mathcal{C} \leftarrow \mathcal{B}} \in \mathbb{F}^{m \times d}$,

并有

$$[T(\mathbf{v})]_{\mathcal{C}} = [T]_{\mathcal{C} \leftarrow \mathcal{B}} [\mathbf{v}]_{\mathcal{B}}. \quad (5.6)$$

矩阵的列数由输入空间维数决定，行数由输出空间维数决定。线性映射是坐标无关的对象，矩阵则依赖输入端和输出端各自选用的基。

设计矩阵 $\mathbf{X}_{\varepsilon} \in \mathbb{R}^{3 \times 2}$ 表示线性映射

$$T_{\varepsilon} : \mathbb{R}^2 \rightarrow \mathbb{R}^3, \quad T_{\varepsilon}(\mathbf{w}) = \mathbf{X}_{\varepsilon} \mathbf{w}.$$

输入 $\mathbf{w} = (w_1, w_2)^{\top}$ 给出两列特征的组合系数，输出 $w_1 \mathbf{c}_1 + w_2 \mathbf{c}_2$ 是三个样本上的拟合向量。这里输入空间与输出空间不同，所以不能把“系数向量”和“拟合向量”视为同一个对象。

5.2.2 矩阵乘法表达映射复合

若 $T : U \rightarrow V$ 与 $S : V \rightarrow W$ 都是线性映射，则复合 $S \circ T : U \rightarrow W$ 仍为线性映射。在相容的基下，其矩阵满足

$$[S \circ T] = [S][T].$$

这解释了矩阵乘法为何按“左矩阵的行乘右矩阵的列”定义。若 $\mathbf{A} \in \mathbb{F}^{m \times d}$ 且 $\mathbf{B} \in \mathbb{F}^{d \times k}$ ，那么

$$(\mathbf{AB})_{i,j} = \sum_{\ell=1}^d a_{i,\ell} b_{\ell,j}, \quad \mathbf{AB} \in \mathbb{F}^{m \times k}. \quad (5.7)$$

被求和的中间索引 ℓ 对应复合映射的中间空间。维度不匹配意味着两个映射不能按该次序复合，而不仅是书写格式有误。

复合的先后通常不能交换。即使 $\mathbf{AB}$ 和 $\mathbf{BA}$ 都能定义，它们也可能不同。例如

$$\begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix} = \begin{bmatrix} 0 & 1 \\ 0 & 0 \end{bmatrix}, \quad \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix} \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix} = \begin{bmatrix} 0 & 0 \\ 1 & 0 \end{bmatrix}.$$

前者先交换坐标再保留第一坐标，后者先保留第一坐标再交换；两个过程的输出自然不同。

5.2.3 转置、共轭转置与逆映射

实矩阵 $\mathbf{A} \in \mathbb{R}^{m \times d}$ 的**转置** (transpose) $\mathbf{A}^{\top} \in \mathbb{R}^{d \times m}$ 交换行列, $(\mathbf{A}^{\top})_{i,j} = a_{j,i}$ 。它满足

$$(\mathbf{AB})^{\top} = \mathbf{B}^{\top} \mathbf{A}^{\top}.$$

次序反转是因为转置后的映射要按相反方向与内积配对。对复矩阵，还要同时取复共轭，得到**共轭转置** (conjugate transpose) $\mathbf{A}^* = \overline{\mathbf{A}}^\top$ 。实矩阵是复矩阵的特殊情形，此时 $\mathbf{A}^* = \mathbf{A}^\top$ 。

方阵 $\mathbf{A} \in \mathbb{F}^{d \times d}$ 若存在 $\mathbf{A}^{-1}$ 使

$$\mathbf{A}^{-1}\mathbf{A} = \mathbf{A}\mathbf{A}^{-1} = \mathbf{I}_d,$$

就称为可逆矩阵。它表示一个双射线性映射， $\mathbf{A}^{-1}$ 表示逆映射。可逆性等价于列向量线性无关，也等价于列向量张成 $\mathbb{F}^d$ 。非方矩阵不能拥有上述双侧逆；某些非方矩阵可以有单侧逆，但这只对应单射或满射中的一项。

同一个线性算子 $T: V \rightarrow V$ 在两组基 $\mathcal{B}$ 和 $\mathcal{C}$ 下的矩阵记为 $\mathbf{A}_{\mathcal{B}}$ 与 $\mathbf{A}_{\mathcal{C}}$ 。若 $\mathbf{S} = \mathbf{S}_{\mathcal{C} \leftarrow \mathcal{B}}$ ，由式(5.5)在输入和输出两端各换一次坐标，可得

$$\mathbf{A}_{\mathcal{C}} = \mathbf{S}\mathbf{A}_{\mathcal{B}}\mathbf{S}^{-1}. \quad (5.8)$$

这类矩阵称为相似矩阵。矩阵元素随基改变，但映射是否可逆、像空间维数等性质不变。

5.2.4 行列式检测方阵是否压扁体积

对 $\mathbf{A} \in \mathbb{F}^{d \times d}$ ，**行列式** (determinant) $\det(\mathbf{A})$ 是一个标量。它可以由三项性质刻画：对每一列分别线性，交换两列会变号，且 $\det(\mathbf{I}_d) = 1$ 。在实坐标中， $\det(\mathbf{A})$ 给出有向体积的缩放因子：其绝对值 $|\det(\mathbf{A})|$ 是普通体积的缩放倍数，其符号则记录定向保持还是反转。

若矩阵列向量线性相关，它们张成的平行多面体被压到更低维空间，体积为零，因而 $\det(\mathbf{A}) = 0$ 。反过来， $\det(\mathbf{A}) \neq 0$ 当且仅当 $\mathbf{A}$ 可逆，并有

$$\det(\mathbf{AB}) = \det(\mathbf{A})\det(\mathbf{B}), \quad \det(\mathbf{A}^{-1}) = \frac{1}{\det(\mathbf{A})}.$$

从近共线矩阵的前两行取出方阵

$$\mathbf{A}_\varepsilon = \begin{bmatrix} 1 & 1 \\ 1 & 1 + \varepsilon \end{bmatrix}, \quad \det(\mathbf{A}_\varepsilon) = \varepsilon.$$

当 $\varepsilon = 0$ 时，两列张成的平行四边形面积为零；当 $|\varepsilon|$ 很小时，面积虽非零却很小。行列式能检验精确可逆性，但单独看一个可能随维数和整体缩放快速变化的数，并不足以完整描述数值稳定性。

5.2.5 四个基本子空间说明信息流向

对 $A \in \mathbb{F}^{m \times d}$, 它的**列空间** (column space) 是

$$\text{col}(A) = \{Ax : x \in \mathbb{F}^d\} \subseteq \mathbb{F}^m,$$

也就是线性映射能够到达的全部输出。它的**零空间** (null space) 是

$$\text{null}(A) = \{x \in \mathbb{F}^d : Ax = \mathbf{0}\},$$

记录输入中被映射完全消去的方向。行向量在 $\mathbb{F}^d$ 中张成**行空间** (row space) $\text{row}(A)$ 。相应地, $\text{null}(A^*) \subseteq \mathbb{F}^m$ 记录与所有列向量正交的输出生方向。

列空间的维数称为矩阵的**秩** (rank), 记作 $\text{rank}(A)$; 零空间的维数称为零度。行秩与列秩相等, 所以秩既可理解为独立输出方向的数量, 也可理解为独立行约束的数量¹。

¹ S. Axler, *Linear Algebra Done Right*, Springer, 2015, 3rd ed.

定理 5.1 秩零度定理 设 $T : V \rightarrow W$ 是有限维向量空间之间的线性映射, 则

$$\dim V = \dim \text{null}(T) + \dim \text{range}(T).$$

对矩阵 $A \in \mathbb{F}^{m \times d}$, 这写成

$$d = \dim \text{null}(A) + \text{rank}(A).$$

证明. 取 $\text{null}(T)$ 的一组基 $(v_1, \dots, v_r)$, 并把它扩充为 V 的一组基

$$(v_1, \dots, v_r, v_{r+1}, \dots, v_d).$$

任意 $v \in V$ 都是这些基向量的线性组合, 而前 r 个向量经 T 后为零, 所以 $T(v_{r+1}), \dots, T(v_d)$ 张成 $\text{range}(T)$ 。

还需检查这些像线性无关。若

$$\sum_{j=r+1}^d a_j T(v_j) = \mathbf{0},$$

则 $T(\sum_{j=r+1}^d a_j v_j) = \mathbf{0}$, 故该线性组合属于 $\text{null}(T)$, 可以由 $v_1, \dots, v_r$ 表示。由于 $v_1, \dots, v_d$ 线性无关, 只能有 $a_{r+1} = \dots = a_d = 0$ 。因此这些像构成值域的一组基, 值域维数为 $d - r$, 结论成立。■

对 X_ε , 当 $\varepsilon \neq 0$ 时秩为 2, 零空间只有 $\mathbf{0}$; 当 $\varepsilon = 0$ 时秩降为 1, 并且

$$\text{null}(X_0) = \text{span}\{(1, -1)^\top\}.$$

沿 $(1, -1)^\top$ 改变系数不会改变拟合输出，因为两列对这一增减正好抵消。

5.2.6 线性方程的解由列空间和零空间共同决定

线性方程组

$$\mathbf{Ax} = \mathbf{b}, \quad \mathbf{A} \in \mathbb{F}^{m \times d}, \quad \mathbf{x} \in \mathbb{F}^d, \quad \mathbf{b} \in \mathbb{F}^m \quad (5.9)$$

有解，当且仅当 $\mathbf{b} \in \text{col}(\mathbf{A})$ 。若 $\mathbf{x}_0$ 是一个特解，那么全部解恰为

$$\mathbf{x}_0 + \text{null}(\mathbf{A}) = \{\mathbf{x}_0 + \mathbf{z} : \mathbf{z} \in \text{null}(\mathbf{A})\}.$$

确实， $\mathbf{A}(\mathbf{x}_0 + \mathbf{z}) = \mathbf{b}$ ；反过来，任何另一个解 $\mathbf{x}$ 都满足 $\mathbf{A}(\mathbf{x} - \mathbf{x}_0) = \mathbf{0}$ 。所以有解时，解唯一当且仅当零空间只含零向量。

这给出三种情形： $\mathbf{b}$ 不在列空间中时无解； $\mathbf{b}$ 在列空间且零空间平凡时有唯一解； $\mathbf{b}$ 在列空间且零空间非平凡时有无穷多个解。方程个数多于未知数并不自动导致无解，方程个数少也不自动导致多解，真正决定条件的是列空间与零空间。

对式 (5.3)，当 $\varepsilon \neq 0$ 时，式 (5.4) 给出 $\mathbf{X}_\varepsilon \mathbf{w} = \mathbf{y}$ 的唯一解。当 $\varepsilon = 0$ 且 $\delta \neq 0$ 时， $\mathbf{y} \notin \text{span}\{\mathbf{c}_1\}$ ，方程无解。下一节将引入长度与距离，使“无解时寻找最接近的可达输出”成为一个明确问题。

5.3 长度、角度与距离

5.3.1 内积把代数关系变成几何关系

在实向量空间中，**内积** (inner product) $\langle \cdot, \cdot \rangle : V \times V \rightarrow \mathbb{R}$ 对第一个变量和第二个变量分别线性，满足对称性 $\langle \mathbf{x}, \mathbf{y} \rangle = \langle \mathbf{y}, \mathbf{x} \rangle$ ，并且

$$\langle \mathbf{x}, \mathbf{x} \rangle \geq 0, \quad \langle \mathbf{x}, \mathbf{x} \rangle = 0 \iff \mathbf{x} = \mathbf{0}.$$

在 $\mathbb{R}^d$ 中，标准内积是 $\langle \mathbf{x}, \mathbf{y} \rangle = \mathbf{x}^\top \mathbf{y}$ 。复向量空间中的标准内积采用 $\langle \mathbf{x}, \mathbf{y} \rangle = \mathbf{x}^* \mathbf{y}$ ；它对一个变量共轭线性，以保证 $\langle \mathbf{x}, \mathbf{x} \rangle$ 仍为非负实数。

本书在复空间中约定内积对第一个变量共轭线性、对第二个变量线性，并满足共轭对称性

$$\langle \mathbf{x}, \mathbf{y} \rangle = \overline{\langle \mathbf{y}, \mathbf{x} \rangle}.$$

普通转置不能保证这些性质，这正是复数情形使用共轭转置的原因。

内积诱导长度

$$\|\mathbf{x}\| = \sqrt{\langle \mathbf{x}, \mathbf{x} \rangle}. \quad (5.10)$$

以下夹角公式限于实内积空间；复内积可能取非实值，若要定义复空间中

的夹角, 还需另行选择只使用模或实部的约定。

两个非零向量的夹角 $\theta \in [0, \pi]$ 由

$$\cos \theta = \frac{\langle \mathbf{x}, \mathbf{y} \rangle}{\|\mathbf{x}\| \|\mathbf{y}\|}$$

定义。这个比值确实落在 $[-1, 1]$ 中, 依据是下面的不等式。

定理 5.2 Cauchy-Schwarz 不等式 在实或复内积空间中,

$$|\langle \mathbf{x}, \mathbf{y} \rangle| \leq \|\mathbf{x}\| \|\mathbf{y}\|.$$

等号成立当且仅当 $\mathbf{x}$ 与 $\mathbf{y}$ 线性相关。

证明. 若 $\mathbf{y} = \mathbf{0}$, 结论直接成立。否则令

$$a = \frac{\langle \mathbf{y}, \mathbf{x} \rangle}{\langle \mathbf{y}, \mathbf{y} \rangle}.$$

由内积的正定性,

$$\begin{aligned} 0 &\leq \|\mathbf{x} - a\mathbf{y}\|^2 \\ &= \|\mathbf{x}\|^2 - \frac{|\langle \mathbf{x}, \mathbf{y} \rangle|^2}{\|\mathbf{y}\|^2}. \end{aligned}$$

移项并乘以 $\|\mathbf{y}\|^2$ 便得到所需不等式。等号成立恰好意味着 $\mathbf{x} - a\mathbf{y} = \mathbf{0}$, 也就是两向量线性相关。 ■

若 $\langle \mathbf{x}, \mathbf{y} \rangle = 0$, 就称 $\mathbf{x}$ 与 $\mathbf{y}$ **正交** (orthogonal)。式 (5.1) 中的 $\mathbf{c}_1$ 与 $\mathbf{q}$ 正交, 因为 $\mathbf{c}_1^\top \mathbf{q} = 0$ 。因此

$$\langle \mathbf{c}_1, \mathbf{c}_2 \rangle = 3, \quad \|\mathbf{c}_1\|_2 = \sqrt{3}, \quad \|\mathbf{c}_2\|_2 = \sqrt{3 + 2\varepsilon^2},$$

从而

$$\cos \theta_\varepsilon = \frac{\sqrt{3}}{\sqrt{3 + 2\varepsilon^2}}. \quad (5.11)$$

当 $\varepsilon \rightarrow 0$ 时, $\cos \theta_\varepsilon \rightarrow 1$, 夹角趋于 0。这里“近”使用的是欧氏夹角; 换用别的内积, 角度也会随之改变。

5.3.2 范数和距离明确误差按什么尺度计算

范数 (norm) $\|\cdot\| : V \rightarrow [0, \infty)$ 为向量指定大小, 并满足

$$\|\mathbf{x}\| = 0 \iff \mathbf{x} = \mathbf{0}, \quad \|a\mathbf{x}\| = |a|\|\mathbf{x}\|, \quad \|\mathbf{x} + \mathbf{y}\| \leq \|\mathbf{x}\| + \|\mathbf{y}\|.$$

第三条是**三角不等式** (triangle inequality), 它表达绕经中间点不会比直接距离更短。并非每个范数都来自内积; 例如 ℓ_1 范数和 ℓ_∞ 范数通常没有一个内积能通过式 (5.10) 产生。

内积诱导的范数必定满足平行四边形恒等式

$$\|\mathbf{x} + \mathbf{y}\|^2 + \|\mathbf{x} - \mathbf{y}\|^2 = 2\|\mathbf{x}\|^2 + 2\|\mathbf{y}\|^2.$$

第4章式 (4.2) 说明, 这也是一个范数能由内积诱导的判据。例如在 $\mathbb{R}^2$ 中取 $\mathbf{x} = (1, 0)^\top$ 和 $\mathbf{y} = (0, 1)^\top$, ℓ_1 范数下等式左侧为 8、右侧为 4, 所以 ℓ_1 范数不来自内积。

坐标范数及其对偶需要先固定线性配对。以下在 $\mathbb{F}^d$ 上采用标准坐标配对 $\langle \mathbf{x}, \mathbf{y} \rangle = \mathbf{x}^* \mathbf{y}$, 而不沿用任意给定的内积。对 $\mathbf{x} \in \mathbb{F}^d$ 和 $1 \leq p < \infty$, 定义

$$\|\mathbf{x}\|_p = \left(\sum_{j=1}^d |x_j|^p \right)^{1/p}, \quad \|\mathbf{x}\|_\infty = \max_{1 \leq j \leq d} |x_j|.$$

其中 $p = 2$ 给出标准内积诱导的欧氏范数。任一范数都诱导距离

$$d(\mathbf{x}, \mathbf{y}) = \|\mathbf{x} - \mathbf{y}\|.$$

距离比较的是差向量, 而不是两个坐标列表各自的大小。不同范数强调不同误差: ℓ_∞ 控制最大坐标偏差, ℓ_1 累加绝对偏差, ℓ_2 则累加平方后开方。

对欧氏范数, 三角不等式可由定理 5.2 直接推出:

$$\|\mathbf{x} + \mathbf{y}\|_2^2 = \|\mathbf{x}\|_2^2 + 2\operatorname{Re}\langle \mathbf{x}, \mathbf{y} \rangle + \|\mathbf{y}\|_2^2 \leq (\|\mathbf{x}\|_2 + \|\mathbf{y}\|_2)^2.$$

两边非负, 开平方即得结论。一般 ℓ_p 范数的三角不等式可由 Hölder 不等式推出。

下面的证明会用到 Young 不等式。若 $1 < p, q < \infty$ 且 $1/p + 1/q = 1$, 则对任意 $u, v \geq 0$,

$$uv \leq \frac{u^p}{p} + \frac{v^q}{q}.$$

它有一个简短的微积分证明。 $u = 0$ 时结论直接成立; 若 $u > 0$, 令 $t = v/u^{p-1}$, 则所需不等式除以 u^p 后等价于 $t \leq 1/p + t^q/q$ 。函数 $g(t) = 1/p + t^q/q - t$ 在 $t \geq 0$ 上满足 $g'(t) = t^{q-1} - 1$, 因而在 $t = 1$ 处取得最小值 $g(1) = 0$ 。

定理 5.3 有限维 Hölder 不等式 设 $1 \leq p, q \leq \infty$ 且 $1/p + 1/q = 1$,

其中 $1/\infty = 0$ 。在上述标准坐标配对下, 对任意 $\mathbf{x}, \mathbf{y} \in \mathbb{F}^d$,

$$|\langle \mathbf{x}, \mathbf{y} \rangle| \leq \|\mathbf{x}\|_p \|\mathbf{y}\|_q.$$

证明. 先设 $1 < p, q < \infty$, 且两个向量都非零。令 $u_j = |x_j|/\|\mathbf{x}\|_p$ 和 $v_j = |y_j|/\|\mathbf{y}\|_q$ 。Young 不等式 $uv \leq u^p/p + v^q/q$ 给出

$$\sum_{j=1}^d u_j v_j \leq \frac{1}{p} \sum_{j=1}^d u_j^p + \frac{1}{q} \sum_{j=1}^d v_j^q = \frac{1}{p} + \frac{1}{q} = 1.$$

再用 $|\langle \mathbf{x}, \mathbf{y} \rangle| \leq \sum_j |x_j| |y_j|$ 并恢复尺度, 即得结论。若某个向量为零, 结论直接成立。端点 $p = 1, q = \infty$ 时,

$$\sum_{j=1}^d |x_j| |y_j| \leq \left(\max_j |y_j| \right) \sum_{j=1}^d |x_j| = \|\mathbf{x}\|_1 \|\mathbf{y}\|_\infty;$$

另一端点对称成立。 ■

5.3.3 对偶范数控制允许扰动中的最大线性变化

知道扰动 $\mathbf{r}$ 很小, 还不足以判断一个线性量 $\langle \mathbf{z}, \mathbf{r} \rangle$ 最多变化多少, 因为“小”必须相对于某个范数说明。这里仍用标准坐标配对把 $\mathbf{z}$ 识别为线性泛函。给定范数 $\|\cdot\|$, 其**对偶范数** (dual norm) 定义为

$$\|\mathbf{z}\|_* = \max_{\|\mathbf{r}\| \leq 1} |\langle \mathbf{z}, \mathbf{r} \rangle|. \quad (5.12)$$

它表示在原范数单位球允许的全部扰动中, 线性函数 $\mathbf{r} \mapsto \langle \mathbf{z}, \mathbf{r} \rangle$ 能够达到的最大绝对变化。有限维单位球是紧集, 目标函数连续, 所以这里的最大值确实能够达到。

Hölder 不等式立即给出 ℓ_p 与 ℓ_q 的配对上界, 其中 $1/p + 1/q = 1$:

$$|\langle \mathbf{z}, \mathbf{r} \rangle| \leq \|\mathbf{z}\|_q \|\mathbf{r}\|_p.$$

这个上界还能达到。当 $1 < p < \infty$ 且 $\mathbf{z} \neq \mathbf{0}$ 时, 取

$$r_j = \begin{cases} \frac{z_j}{|z_j|} \frac{|z_j|^{q-1}}{\|\mathbf{z}\|_q^{q-1}}, & z_j \neq 0, \\ 0, & z_j = 0. \end{cases},$$

可核对 $\|\mathbf{r}\|_p = 1$ 且 $\langle \mathbf{z}, \mathbf{r} \rangle = \|\mathbf{z}\|_q$ 。端点 $p = 1$ 时, 在 $|z_j|$ 最大的一个坐标上取与 z_j 相同的相位, 其余坐标取零; 端点 $p = \infty$ 时, 每个非零坐标都

取与 $\mathbf{z}_j$ 相同的相位，零坐标仍取零。 $\mathbf{z} = \mathbf{0}$ 时上界平凡达到。因此

$$(\|\cdot\|_p)_* = \|\cdot\|_q, \quad \frac{1}{p} + \frac{1}{q} = 1. \quad (5.13)$$

特别地， ℓ_2 与自身对偶， ℓ_1 与 ℓ_∞ 互为对偶。

若允许扰动满足 $\|\mathbf{r}\|_p \leq \rho$ ，对偶范数的定义经缩放给出

$$\max_{\|\mathbf{r}\|_p \leq \rho} |\langle \mathbf{z}, \mathbf{r} \rangle| = \rho \|\mathbf{z}\|_q. \quad (5.14)$$

例如 $\mathbf{z} = (2, -1)^\top$ 且每个扰动坐标满足 $|r_j| \leq 0.01$ ，也就是 $\|\mathbf{r}\|_\infty \leq 0.01$ ，则最大绝对变化为 $0.01\|\mathbf{z}\|_1 = 0.03$ ，由 $\mathbf{r} = (0.01, -0.01)^\top$ 达到。这个结论只控制线性函数；把它用于非线性模型的有限扰动时，还必须另外控制线性近似的余项。

这里的“对偶”是相对于一个范数单位球最大化线性函数，从而为向量 $\mathbf{z}$ 定义另一个范数。第 3.7 节的拉格朗日对偶则从约束优化问题构造对偶函数和最优值下界，研究对象是原问题与对偶问题之间的关系。两者都出现线性配对，但定义、输出和用途不同，不能把对偶范数直接当作某个优化问题的拉格朗日对偶。

目共线坐标也可用这一语言观察。式(5.4)中第二个坐标为 δ/ε ，所以目标沿 $\mathbf{q}$ 方向改变 $\Delta\delta$ 时，该坐标改变 $\Delta\delta/\varepsilon$ 。这是特定坐标映射对该方向扰动的放大；要对所有方向给出统一上界，需要下一章引入矩阵的诱导范数和条件数。

5.3.4 半正定矩阵可以定义方向相关的伪距离

范数给所有位置使用同一套长度规则，矩阵则可以为不同方向指定不同权重。若实矩阵 $\mathbf{M} \in \mathbb{R}^{d \times d}$ 对称正定，则

$$\langle \mathbf{x}, \mathbf{y} \rangle_{\mathbf{M}} = \mathbf{x}^\top \mathbf{M} \mathbf{y}, \quad \|\mathbf{x}\|_{\mathbf{M}} = \sqrt{\mathbf{x}^\top \mathbf{M} \mathbf{x}}$$

分别定义内积及其诱导范数。对称性给出内积的对称性，双线性来自矩阵乘法，正定性保证非零向量的平方长度严格为正；Cauchy-Schwarz 不等式再保证三角不等式。因此 $d_{\mathbf{M}}(\mathbf{x}, \mathbf{y}) = \|\mathbf{x} - \mathbf{y}\|_{\mathbf{M}}$ 确实是距离。

欧氏距离对所有方向一视同仁，但有些问题需要让不同方向承担不同权重。设 $\mathbf{M} \in \mathbb{R}^{d \times d}$ 为对称半正定矩阵，即对每个 $\mathbf{z} \in \mathbb{R}^d$ 都有 $\mathbf{z}^\top \mathbf{M} \mathbf{z} \geq 0$ 。定义

$$d_{\mathbf{M}}(\mathbf{x}, \mathbf{y}) = \sqrt{(\mathbf{x} - \mathbf{y})^\top \mathbf{M} (\mathbf{x} - \mathbf{y})}. \quad (5.15)$$

若 $\mathbf{M} = \mathbf{L}^\top \mathbf{L}$ ，那么 $d_{\mathbf{M}}(\mathbf{x}, \mathbf{y}) = \|\mathbf{L}(\mathbf{x} - \mathbf{y})\|_2$ 。因此非负性、对称性和三角不等式都继承自欧氏范数。

每个实对称半正定矩阵都存在这样的分解；第6.4节将构造方阵谱平方根 $\mathbf{L} = \mathbf{M}^{1/2} \in \mathbb{R}^{d \times d}$ 。当 $\mathbf{M}$ 正定时，这个方阵因子可逆，换坐标 $\mathbf{x} \mapsto \mathbf{L}\mathbf{x}$ 把 $\mathbf{M}$ 诱导的几何转成欧氏几何；半正定情形中 $\mathbf{L}$ 可以消去非零方向，因而还要检查距离的可分辨性。

半正定性却不保证不同向量之间的距离为正。取

$$\mathbf{M} = \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix}.$$

点 $(0,0)^\top$ 与 $(0,1)^\top$ 不同，但它们的 $d_{\mathbf{M}}$ 距离为 0，因为第二个方向被完全忽略。这种满足距离其余性质、却可能令不同对象距离为零的函数称为**伪距离** (pseudometric)。只有当 $\mathbf{M}$ 正定，也就是对所有非零 $\mathbf{z}$ 均有 $\mathbf{z}^\top \mathbf{M} \mathbf{z} > 0$ 时，式(5.15)才区分任意两个不同向量，成为真正的距离。

权重矩阵改变的是几何判断。若用 $\mathbf{M}$ 比较特征或表示，就应说明哪些方向被强调、哪些方向被忽略，以及这种选择为何适合当前任务。半正定矩阵造成的零距离不表示两个原始对象相等，只表示所选几何无法区分它们。

5.4 正交投影与最小二乘

5.4.1 正交投影寻找子空间中最近的向量

当线性方程 $\mathbf{A}\mathbf{x} = \mathbf{b}$ 无解时， $\mathbf{b}$ 不在 $\text{col}(\mathbf{A})$ 中。若采用欧氏距离，一个自然替代问题是在列空间中寻找离 $\mathbf{b}$ 最近的向量。设 U 是有限维内积空间 V 的线性子空间。**正交投影** (orthogonal projection) 把 $\mathbf{y} \in V$ 分解为

$$\mathbf{y} = \hat{\mathbf{y}} + \mathbf{r}, \quad \hat{\mathbf{y}} \in U, \quad \mathbf{r} \perp U.$$

其中 $\hat{\mathbf{y}}$ 称为 $\mathbf{y}$ 在 U 上的投影， $\mathbf{r}$ 是残差²。

有限维子空间自动是闭集。把定理4.1中的闭凸集取为线性子空间 U ，便得到投影的存在唯一性；该章还证明了线性子空间情形的最近点条件等价于残差正交，这里不再重复证明。正交性还直接给出最近点的距离分解：对任意 $\mathbf{u} \in U$ ，由于 $\hat{\mathbf{y}} - \mathbf{u} \in U$ ，

$$\|\mathbf{y} - \mathbf{u}\|^2 = \|\mathbf{r}\|^2 + \|\hat{\mathbf{y}} - \mathbf{u}\|^2.$$

第二项非负，且仅在 $\mathbf{u} = \hat{\mathbf{y}}$ 时为零，所以投影确实是 U 中的唯一最近点。有限维坐标仍可直接写出：取 U 的一组标准正交基 $(\mathbf{q}_1, \dots, \mathbf{q}_r)$ ，则

$$\hat{\mathbf{y}} = \sum_{j=1}^r \langle \mathbf{q}_j, \mathbf{y} \rangle \mathbf{q}_j.$$

² S. Axler, *Linear Algebra Done Right*, Springer, 2015, 3rd ed.

每个系数都是 $\mathbf{y}$ 沿对应基方向的分量。

若 $\mathbf{Q} \in \mathbb{F}^{m \times r}$ 的列组成 U 的一组标准正交基, 即 $\mathbf{Q}^* \mathbf{Q} = \mathbf{I}_r$, 那么投影写成

$$\hat{\mathbf{y}} = \mathbf{Q} \mathbf{Q}^* \mathbf{y}, \quad \mathbf{P}_U = \mathbf{Q} \mathbf{Q}^*. \quad (5.16)$$

投影矩阵满足 $\mathbf{P}_U^* = \mathbf{P}_U$ 和 $\mathbf{P}_U^2 = \mathbf{P}_U$: 它是自伴的, 而且投影一次后再次投影不会改变结果。

5.4.2 正规方程来自残差正交

给定 $\mathbf{X} \in \mathbb{R}^{n \times d}$ 和 $\mathbf{y} \in \mathbb{R}^n$, **最小二乘** (least squares) 问题是

$$\min_{\mathbf{w} \in \mathbb{R}^d} \|\mathbf{X} \mathbf{w} - \mathbf{y}\|_2^2. \quad (5.17)$$

所有拟合向量 $\mathbf{X} \mathbf{w}$ 恰好组成 $\text{col}(\mathbf{X})$, 所以定理 4.1 保证最近的拟合向量总是存在且唯一。即使系数 $\mathbf{w}$ 不唯一, 拟合向量也不会因此变成多个不同的最近点。

记最优拟合向量为 $\hat{\mathbf{y}} = \mathbf{X} \hat{\mathbf{w}}$, 残差为 $\mathbf{r} = \mathbf{y} - \mathbf{X} \hat{\mathbf{w}}$ 。残差与列空间正交, 当且仅当它与 $\mathbf{X}$ 的每一列正交, 因此

$$\mathbf{X}^\top (\mathbf{y} - \mathbf{X} \hat{\mathbf{w}}) = \mathbf{0}, \quad \text{即} \quad \mathbf{X}^\top \mathbf{X} \hat{\mathbf{w}} = \mathbf{X}^\top \mathbf{y}. \quad (5.18)$$

这就是**正规方程** (normal equations)。“正规”在这里指法向或正交关系, 不表示矩阵已经归一化。

也可以直接从目标函数验证这一条件。对任意增量 $\mathbf{h}$,

$$\begin{aligned} \|\mathbf{X}(\hat{\mathbf{w}} + \mathbf{h}) - \mathbf{y}\|_2^2 &= \|-\mathbf{r} + \mathbf{X} \mathbf{h}\|_2^2 \\ &= \|\mathbf{r}\|_2^2 - 2\mathbf{h}^\top \mathbf{X}^\top \mathbf{r} + \|\mathbf{X} \mathbf{h}\|_2^2. \end{aligned}$$

当式 (5.18) 成立时, 中间项为零, 目标只能增加 $\|\mathbf{X} \mathbf{h}\|_2^2$, 所以正规方程不仅是驻点条件, 也足以保证全局最优。

若 $\text{rank}(\mathbf{X}) = d$, 则对每个非零 $\mathbf{z}$ 都有

$$\mathbf{z}^\top \mathbf{X}^\top \mathbf{X} \mathbf{z} = \|\mathbf{X} \mathbf{z}\|_2^2 > 0.$$

于是 $\mathbf{X}^\top \mathbf{X}$ 正定且可逆, 系数解唯一:

$$\hat{\mathbf{w}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}. \quad (5.19)$$

若秩不足, 存在非零 $\mathbf{z} \in \text{null}(\mathbf{X})$ 。任一最优系数 $\hat{\mathbf{w}}$ 与 $\hat{\mathbf{w}} + \mathbf{z}$ 给出相同拟合向量, 所以系数不唯一。下一章将构造伪逆, 并证明它在这些解中选择欧氏范数最小者。

加权最小二乘 (weighted least squares) 沿用同一个投影问题, 但改用正定权重矩阵 $\mathbf{M} \in \mathbb{R}^{n \times n}$ 衡量残差:

$$\min_{\mathbf{w} \in \mathbb{R}^d} (\mathbf{X}\mathbf{w} - \mathbf{y})^\top \mathbf{M} (\mathbf{X}\mathbf{w} - \mathbf{y}).$$

此时“残差正交”指 $\mathbf{M}$ 内积下的正交, 即

$$\mathbf{X}^\top \mathbf{M} (\mathbf{y} - \mathbf{X}\hat{\mathbf{w}}) = \mathbf{0}, \quad \mathbf{X}^\top \mathbf{M} \mathbf{X} \hat{\mathbf{w}} = \mathbf{X}^\top \mathbf{M} \mathbf{y}. \quad (5.20)$$

正定性使这仍是列空间上的正交投影, 最优拟合向量存在且唯一; 系数仍在 $\mathbf{X}$ 满列秩时才唯一。若权重矩阵仅半正定, 目标可能完全忽略某些残差方向, 前述唯一性结论便不能直接沿用。

5.4.3 近共线例子区分系数、拟合与残差

回到 $\mathbf{X}_\varepsilon$ 与 $\mathbf{y}$ 。由于 $\mathbf{c}_1^\top \mathbf{q} = 0$ 且 $\|\mathbf{q}\|_2^2 = 2$,

$$\mathbf{X}_\varepsilon^\top \mathbf{X}_\varepsilon = \begin{bmatrix} 3 & 3 \\ 3 & 3 + 2\varepsilon^2 \end{bmatrix}, \quad \mathbf{X}_\varepsilon^\top \mathbf{y} = \begin{bmatrix} 3 \\ 3 + 2\varepsilon\delta \end{bmatrix}.$$

这个矩阵称为**Gram 矩阵** (Gram matrix), 其行列式为 $6\varepsilon^2$ 。当 $\varepsilon \neq 0$ 时, 正规方程唯一解为

$$\hat{\mathbf{w}}_\varepsilon = \begin{bmatrix} 1 - \delta/\varepsilon \\ \delta/\varepsilon \end{bmatrix}, \quad \mathbf{X}_\varepsilon \hat{\mathbf{w}}_\varepsilon = \mathbf{y}. \quad (5.21)$$

这与式 (5.4) 一致。取 $\varepsilon = 0.01$ 和 $\delta = 0.1$, 系数为 $(-9, 10)^\top$, 拟合残差却恰为零。因此“大系数”和“大训练残差”是不同判断。

再令 $\varepsilon = 0$ 。此时列空间退化为 $U = \text{span}\{\mathbf{c}_1\}$, 而 $\mathbf{y} = \mathbf{c}_1 + \delta\mathbf{q}$ 已经是正交分解。投影与残差分别为

$$\hat{\mathbf{y}}_0 = \mathbf{c}_1, \quad \mathbf{r}_0 = \delta\mathbf{q}, \quad \|\mathbf{r}_0\|_2^2 = 2\delta^2.$$

所有满足 $w_1 + w_2 = 1$ 的系数都给出同一个拟合向量 $\mathbf{c}_1$ 。系数解有无穷多个, 但最优拟合向量仍唯一; 同时, $\delta\mathbf{q}$ 方向已经不在列空间中, 所以不可能把残差降为零。

这个边界还说明一个不连续现象: 对每个非零 ε , 矩阵都能精确拟合 $\mathbf{y}$, 但所需系数的范数随着 $\varepsilon \rightarrow 0$ 而发散; 在极限矩阵 $\mathbf{X}_0$ 上, 目标又不再能够精确拟合。矩阵元素接近并不保证方程解接近。下一章将用小奇异值与条件数定量解释这种敏感性, 并比较正则化和稳定求解保留了什么。

5.5 多维数组与结构运算

5.5.1 形状记录每个索引的取值范围

向量有一个坐标索引，矩阵有行列两个索引。机器学习中的一批序列、图像或特征图还需要批次、位置、通道等更多索引。这里沿用机器学习中的常见说法，把具有固定多个索引的数值数组称为**张量** (tensor)，例如

$$\mathbf{X} \in \mathbb{R}^{b \times \ell \times d}$$

表示含 b 个样本、每个样本有 ℓ 个位置、每个位置有 d 个特征的数组， $x_{i,j,k}$ 是第 i 个样本、第 j 个位置的第 k 个特征。这里的“阶”指索引轴数量，不应与矩阵秩或高阶张量分解中的各种秩混淆。

这种用法描述的是数组的存储形状。几何中的张量对象还必须规定换基时各个坐标索引怎样共同变换，使不同基下的分量表示同一个多线性对象；只有形状相同并不能保证数组满足这种变换规律。本节只需要数组及其索引运算，后文若使用坐标无关的张量对象，将另行说明相应的空间与换基规则。

形状不仅是存储信息，也说明某个运算对哪些索引求和、保留哪些索引。若 $\mathbf{X} \in \mathbb{R}^{b \times \ell \times d}$ 且 $\mathbf{W} \in \mathbb{R}^{d \times h}$ ，对最后一维应用同一个线性映射得到

$$z_{i,j,r} = \sum_{k=1}^d x_{i,j,k} w_{k,r}, \quad \mathbf{Z} \in \mathbb{R}^{b \times \ell \times h}.$$

索引 k 被求和并消失，批次索引 i 、位置索引 j 和输出特征索引 r 保留下来。

维度重排 (permutation of axes) 只改变索引次序，例如把 $b \times \ell \times d$ 改为 $b \times d \times \ell$ ；**形状重整** (reshape) 则在元素总数不变时重新组织索引。它们可以不改变底层数值，却会改变后续运算如何解释各轴。把通道轴误当作位置轴，即使元素数量仍匹配，也会计算另一个映射。因此每次重排都应同时保留各轴的语义，而不能只核对总元素数。

5.5.2 缩并统一求和乘积，逐元素乘法保留形状

张量缩并 (tensor contraction) 选取两个或多个索引轴，逐项相乘并对这些轴求和。矩阵乘法(5.7)就是沿一个共同索引的缩并。更一般地，若

$$\mathbf{A} \in \mathbb{R}^{m \times d \times r}, \quad \mathbf{B} \in \mathbb{R}^{d \times n \times r},$$

沿第二个数组的第一轴与共同的 r 轴缩并可定义

$$c_{i,j} = \sum_{k=1}^d \sum_{s=1}^r a_{i,k,s} b_{k,j,s}, \quad \mathbf{C} \in \mathbb{R}^{m \times n}.$$

写出索引能直接说明哪些维度必须相等，也能避免把本应保留的轴错误求和。

两个同形数组的**逐元素乘积** (Hadamard product) 记作 $\mathbf{A} \odot \mathbf{B}$ ，定义为

$$(\mathbf{A} \odot \mathbf{B})_{i,j} = a_{i,j} b_{i,j}.$$

它保留原形状，不对索引求和，所以通常不同于矩阵乘法。例如

$$\begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix} \odot \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix} = \begin{bmatrix} 0 & 2 \\ 3 & 0 \end{bmatrix},$$

而同样两矩阵的矩阵乘积为 $\begin{bmatrix} 2 & 1 \\ 4 & 3 \end{bmatrix}$ 。门控常使用逐元素乘法，线性层则使用缩并；二者不能因为都写了“乘”而互换。

5.5.3 迹把方阵对角线缩并为标量

方阵 $\mathbf{A} \in \mathbb{F}^{d \times d}$ 的**迹** (trace) 定义为

$$\text{tr}(\mathbf{A}) = \sum_{j=1}^d a_{j,j}.$$

迹是对两个矩阵索引施加相等约束后求和的缩并。只要乘积维度相容，

$$\text{tr}(\mathbf{AB}) = \text{tr}(\mathbf{BA}), \quad (5.22)$$

因为

$$\text{tr}(\mathbf{AB}) = \sum_i \sum_j a_{i,j} b_{j,i} = \sum_j \sum_i b_{j,i} a_{i,j}.$$

对三个以上因子，可以循环移动因子，但不能任意交换次序： $\text{tr}(\mathbf{ABC}) = \text{tr}(\mathbf{BCA})$ ，一般却不等于 $\text{tr}(\mathbf{ACB})$ 。

迹还把矩阵空间上的标准内积写成

$$\langle \mathbf{A}, \mathbf{B} \rangle_{\text{F}} = \text{tr}(\mathbf{A}^* \mathbf{B}) = \sum_{i,j} \overline{a_{i,j}} b_{i,j}.$$

由此诱导的 Frobenius 范数为 $\|\mathbf{A}\|_{\text{F}} = \sqrt{\sum_{i,j} |a_{i,j}|^2}$ 。它把矩阵全部元素排成一个向量后计算欧氏长度；下一章会把它与控制最大方向伸缩的算子范数区分开。

5.5.4 Kronecker 积显式表示成对结构

设 $\mathbf{A} \in \mathbb{F}^{m \times n}$, $\mathbf{B} \in \mathbb{F}^{p \times q}$ 。它们的 **Kronecker 积** (Kronecker product) 是分块矩阵

$$\mathbf{A} \otimes \mathbf{B} = \begin{bmatrix} a_{1,1}\mathbf{B} & \cdots & a_{1,n}\mathbf{B} \\ \vdots & \ddots & \vdots \\ a_{m,1}\mathbf{B} & \cdots & a_{m,n}\mathbf{B} \end{bmatrix} \in \mathbb{F}^{mp \times nq}. \quad (5.23)$$

它不是逐元素乘积, 也不是普通矩阵乘法, 而是把两个索引系统组合成一个较大的线性映射。例如, $\mathbf{A}$ 可以描述第一个索引上的作用, $\mathbf{B}$ 描述第二个索引上的作用, $\mathbf{A} \otimes \mathbf{B}$ 则把两种作用组合到成对索引上。第 6.4 节将统一定义矩阵向量化, 完整推导它与 Kronecker 积的恒等式, 并说明何时可以利用乘积结构而不显式构造大矩阵。

5.5.5 注意力是带多个索引的加权缩并

一个小型**注意力** (attention) 计算可以显示形状如何决定运算。设有 ℓ 个位置, 查询与键的维数为 d_k , 值的维数为 d_v :

$$\mathbf{Q}, \mathbf{K} \in \mathbb{R}^{\ell \times d_k}, \quad \mathbf{V} \in \mathbb{R}^{\ell \times d_v}.$$

分数矩阵与逐行归一化权重定义为

$$\mathbf{S} = \frac{\mathbf{Q}\mathbf{K}^\top}{\sqrt{d_k}} \in \mathbb{R}^{\ell \times \ell}, \quad (5.24)$$

$$a_{i,j} = \frac{\exp(s_{i,j})}{\sum_{r=1}^{\ell} \exp(s_{i,r})}, \quad \mathbf{O} = \mathbf{A}\mathbf{V} \in \mathbb{R}^{\ell \times d_v}. \quad (5.25)$$

式 (5.24) 沿特征索引缩并, 留下两个位置索引; 式 (5.25) 再沿被读取的位置索引缩并, 留下查询位置与值特征索引。权重每行和为 1, 在这里表示归一化加权平均; 概率语义需要另有随机对象支持, 不能只由非负且和为 1 推出。

查询数和键数也可以不同。取两个二维查询、三条二维键和三个标量值,

$$\mathbf{Q} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \in \mathbb{R}^{2 \times 2}, \quad \mathbf{K} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 1 & 1 \end{bmatrix} \in \mathbb{R}^{3 \times 2}, \quad \mathbf{V} = \begin{bmatrix} v_1 \\ v_2 \\ v_3 \end{bmatrix} \in \mathbb{R}^{3 \times 1}.$$

共同的特征维数 2 被缩并, 故

$$\mathbf{Q}\mathbf{K}^\top = \begin{bmatrix} 1 & 0 & 1 \\ 0 & 1 & 1 \end{bmatrix} \in \mathbb{R}^{2 \times 3}.$$

逐行归一化得到 $\mathbf{A} \in \mathbb{R}^{2 \times 3}$ 后, 输出 $\mathbf{A}\mathbf{V} \in \mathbb{R}^{2 \times 1}$; 其中每一行都是 v_1, v_2, v_3

的一次加权缩并。这个例子把“共同特征轴”和“三条被读取的位置轴”分开，说明可乘条件来自被缩并轴，而不要求查询数等于键数。

取 $\ell = d_k = d_v = 2$,

$$Q = K = I_2, \quad V = \begin{bmatrix} 1 & 1 \\ 1 & 1 + \varepsilon \end{bmatrix}.$$

记 $c = \exp(1/\sqrt{2})$, 则

$$A = \frac{1}{c+1} \begin{bmatrix} c & 1 \\ 1 & c \end{bmatrix}, \quad O = \begin{bmatrix} 1 & 1 + \varepsilon/(c+1) \\ 1 & 1 + c\varepsilon/(c+1) \end{bmatrix}.$$

按列比较可得

$$O_{:,2} - O_{:,1} = \frac{\varepsilon}{c+1} \begin{bmatrix} 1 \\ c \end{bmatrix},$$

所以值矩阵的两列接近时，输出两列之差仍为 $O(|\varepsilon|)$ 。按行看， V 的每一行才是一个位置上的值向量，并且 $O_{i,:} = \sum_j a_{i,j} V_{j,:}$ 。因此每个输出行都是原值向量的加权平均，属于 $\text{row}(V)$ ；这个行空间结论与前面的列差关系讨论的是两个不同的索引方向。

5.5.6 卷积窗口是局部共享的缩并

卷积 (convolution) 也可写成索引缩并，但它只连接局部位置，并在不同位置复用同一组核参数。设一个二维输入窗口为 $U \in \mathbb{R}^{k_h \times k_w \times c_{\text{in}}}$ ，卷积核为

$$K \in \mathbb{R}^{k_h \times k_w \times c_{\text{in}} \times c_{\text{out}}}.$$

忽略偏置时，该窗口产生的第 r 个输出通道为

$$z_r = \sum_{a=1}^{k_h} \sum_{b=1}^{k_w} \sum_{s=1}^{c_{\text{in}}} u_{a,b,s} k_{a,b,s,r}. \quad (5.26)$$

三个输入索引被缩并，输出通道索引 r 保留。把窗口移动到另一个位置时，输入元素改变，核参数不变；边界如何补齐、步幅多大以及这里采用卷积还是相关的索引方向，都需要在具体模型中另行说明。

取一个长度为 2、含两个通道的一维窗口

$$U = \begin{bmatrix} 1 & 1 \\ 1 & 1 + \varepsilon \end{bmatrix}.$$

若核 $\mathbf{K}_1$ 的两个位置都取第一通道并赋权 $1/2$ ，输出为 1；若核

$$\mathbf{K}_2 = \begin{bmatrix} 0 & -1 \\ 0 & 1 \end{bmatrix},$$

则缩并结果为 ε ，它提取第二通道在两个位置间的局部变化。前者保留共同方向，后者检测两行之间很小的差异。共享局部核规定了要从每个窗口读取的关系，但这些关系是否适合任务，还取决于输入轴的语义与边界设定。

高阶数组仍可视为一个向量空间中的对象，重排、逐元素乘法和缩并则是不同的运算。某些张量分解会进一步讨论能否用少量因子表示高阶数组，但高阶张量的“秩”存在多种不等价定义，也不像矩阵秩那样共享一套简单结论。本章只建立后续注意力、卷积和结构矩阵所需的形状与运算语言；具体分解在确有需要时再给出相应定义和条件。

5.6 本章小结

线性代数把表示问题拆成几个不能混同的层次。向量是空间中的对象，坐标是对象相对于一组基的系数；线性映射描述作用，矩阵是它在输入、输出基下的表示。张成空间回答哪些输出可以表示，零空间回答哪些输入差异会被消去，秩零度定理把两者联系起来。换基会改变坐标和矩阵元素，却不改变这些空间关系。

内积、范数和正定度量进一步规定怎样比较方向、长度与误差。对偶范数精确给出指定范数球中线性变化的最大值；半正定矩阵可能忽略某些方向，所以只能给出伪距离。正交投影则在选定内积后找到子空间中的唯一最近向量。由此得到的最小二乘拟合向量总是唯一，但系数只有在设计矩阵列满秩时唯一。

贯穿本章的近共线样本显示了这些区别为何必要。 $\varepsilon \neq 0$ 时，两列特征线性无关，能够精确表示目标；随着 ε 趋近 0，表示同一目标所需的系数却不断增大；到 $\varepsilon = 0$ 时，系数不唯一，而且原来沿 $\mathbf{q}$ 方向的目标分量无法拟合。多维数组中的缩并、迹、Kronecker 积、注意力和卷积仍建立在同样的线性组合与索引规则上，形状相容只保证运算有定义，不保证它保留了任务需要的信息。

本章已经说明哪些方向可表示、哪些误差按给定几何衡量，却还没有定量回答线性映射沿不同方向放大或压缩多少。下一章将用特征值、奇异值、矩阵范数和条件数分析这一问题，并据此解释近共线系统中的低秩近似、伪逆、扰动与稳定求解。

矩阵分析

线性代数告诉我们怎样表示线性映射、怎样解线性方程组，但机器学习还会追问一些更细的问题。两个特征几乎重复时，为什么最小二乘系数会对微小噪声极其敏感？压缩一个大矩阵时，保留哪些方向才能使误差最小？计算机返回数值解以后，怎样判断误差来自数据还是求解算法？这些问题不能只用“矩阵是否可逆”回答，还要知道矩阵沿不同方向放大多少、哪些方向几乎被压扁，以及这种结构在扰动下是否稳定。本章继续使用第5章的近共线样本。把输出空间换到 $\mathbf{c}_1/\sqrt{3}$ 与 $\mathbf{q}/\sqrt{2}$ 组成的标准正交坐标，并将整个输出统一除以 $\sqrt{3}$ ，原设计矩阵化为下面的二维表示，其中 $\tilde{\varepsilon} = \sqrt{2/3}\varepsilon$ ：

$$\mathbf{X}_{\tilde{\varepsilon}} = \begin{bmatrix} 1 & 1 \\ 0 & \tilde{\varepsilon} \end{bmatrix}, \quad 0 < \tilde{\varepsilon} \ll 1. \quad (6.1)$$

它的两列是 $\mathbf{x}_1 = (1, 0)^\top$ 与 $\mathbf{x}_2 = (1, \tilde{\varepsilon})^\top$ ，在 $\tilde{\varepsilon}$ 很小时几乎同向。对响应 $\mathbf{y} = (2, 0)^\top$ ，方程 $\mathbf{X}_{\tilde{\varepsilon}}\boldsymbol{\beta} = \mathbf{y}$ 的解是 $\boldsymbol{\beta} = (2, 0)^\top$ ；若把响应改为 $\mathbf{y} + \Delta\mathbf{y} = (2, \eta)^\top$ ，解就变成

$$\boldsymbol{\beta} + \Delta\boldsymbol{\beta} = \begin{bmatrix} 2 - \eta/\tilde{\varepsilon} \\ \eta/\tilde{\varepsilon} \end{bmatrix}. \quad (6.2)$$

响应只改变 $|\eta|$ ，两个系数却分别改变 $|\eta|/\tilde{\varepsilon}$ ，而预测向量只从 $(2, 0)^\top$ 变为 $(2, \eta)^\top$ 。参数敏感与预测敏感不是同一件事；“几乎重复的列”背后存在一个被矩阵强烈压缩的方向。

我们先用特征值和奇异值找出这些方向，再讨论低秩近似怎样舍弃不可靠方向。矩阵范数将方向性结论汇总成尺度，矩阵函数与结构化恒等式帮助操纵大型线性变换；条件数和扰动理论区分问题敏感性与算法误差，稳定求解方法则把这些认识落实为计算策略。

6.1 谱揭示矩阵沿哪些方向作用

6.1.1 特征值描述不改变方向的缩放

给定方阵 $\mathbf{A} \in \mathbb{R}^{d \times d}$ ，若存在非零向量 $\mathbf{v} \in \mathbb{C}^d$ 和标量 $\lambda \in \mathbb{C}$ 使

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{v}. \quad (6.3)$$

则称 λ 是 $\mathbf{A}$ 的**特征值** (eigenvalue)， $\mathbf{v}$ 是对应的**特征向量** (eigenvector)。这意味着 $\mathbf{A}$ 保持 $\mathbf{v}$ 张成的一维复子空间不变，并把长度缩放为原来的 $|\lambda|$ 倍。对实特征值， $\lambda < 0$ 还会使方向反向；对非实特征值，作用中还包含复相位的变化。实矩阵也可能有复特征值，因此定义允许在 $\mathbb{C}$ 中寻找特征对。

式 (6.3) 等价于 $(\mathbf{A} - \lambda\mathbf{I})\mathbf{v} = \mathbf{0}$ 。非零解存在当且仅当

$$p_{\mathbf{A}}(\lambda) = \det(\lambda\mathbf{I} - \mathbf{A}) = 0. \quad (6.4)$$

其中 $p_{\mathbf{A}}$ 称为特征多项式。一个特征值作为多项式根出现的次数是它的代数重数，对应特征空间 $\{\mathbf{v} : \mathbf{A}\mathbf{v} = \lambda\mathbf{v}\}$ 的维数是几何重数。几何重数不超过代数重数；两者不等时，矩阵可能没有足够多的线性无关特征向量。

若 $\mathbf{A}$ 有 d 个线性无关特征向量，把它们按列组成 $\mathbf{V}$ ，把对应特征值放入对角矩阵 $\mathbf{\Lambda}$ ，便有

$$\mathbf{A}\mathbf{V} = \mathbf{V}\mathbf{\Lambda}, \quad \mathbf{A} = \mathbf{V}\mathbf{\Lambda}\mathbf{V}^{-1}.$$

这称为特征分解或对角化。对角形式使幂运算变得直接： $\mathbf{A}^k = \mathbf{V}\mathbf{\Lambda}^k\mathbf{V}^{-1}$ 。但 $\mathbf{V}$ 若接近奇异，坐标变换本身会放大误差；所以非对称矩阵即使可以对角化，也不一定适合直接用特征向量进行数值计算。

即使矩阵不能对角化，它的高次幂也不是彼此独立的新对象。**Cayley-Hamilton 定理** (Cayley-Hamilton theorem) 断言，每个方阵都满足自己的特征多项式。若

$$p_{\mathbf{A}}(t) = t^d + c_{d-1}t^{d-1} + \cdots + c_1t + c_0,$$

则

$$p_{\mathbf{A}}(\mathbf{A}) = \mathbf{A}^d + c_{d-1}\mathbf{A}^{d-1} + \cdots + c_1\mathbf{A} + c_0\mathbf{I} = \mathbf{0}.$$

因此 $\mathbf{A}^d$ 可以写成 $\mathbf{I}, \mathbf{A}, \dots, \mathbf{A}^{d-1}$ 的线性组合；反复代入后，任意更高次幂也可以。这个结论不要求 $\mathbf{A}$ 可对角化。第 18 章分析线性系统的可达空间时，将用它说明超过状态维数的矩阵幂不会产生新的可达方向。

6.1.2 实对称矩阵具有正交谱分解

机器学习中常见的协方差矩阵、Gram 矩阵和 Hessian 矩阵都是实对称矩阵。对称性带来比一般方阵强得多的结论¹。

¹ R. A. Horn, C. R. Johnson, *Matrix Analysis*, Cambridge University Press, 2013, 2nd ed.

定理 6.1 实对称矩阵的谱定理 若 $A \in \mathbb{R}^{d \times d}$ 且 $A^\top = A$, 则它的全部特征值都是实数, 并存在正交矩阵 Q 与实对角矩阵 Λ 使

$$A = Q\Lambda Q^\top. \quad (6.5)$$

证明. 先把 A 看作复矩阵。若 $A\mathbf{v} = \lambda\mathbf{v}$ 且 $\mathbf{v} \neq \mathbf{0}$, 则 $\mathbf{v}^* A \mathbf{v} = \lambda \mathbf{v}^* \mathbf{v}$ 。左侧因 $A^* = A$ 而为实数, 故 λ 为实数; 把 $\mathbf{v}$ 拆成实部与虚部, 其中至少一个给出非零实特征向量。不同特征值对应的向量满足

$$\lambda_j \mathbf{v}_i^\top \mathbf{v}_j = \mathbf{v}_i^\top A \mathbf{v}_j = (A \mathbf{v}_i)^\top \mathbf{v}_j = \lambda_i \mathbf{v}_i^\top \mathbf{v}_j,$$

所以二者正交。

对维数归纳。取一个实单位特征向量 $\mathbf{q}_1$ 。若 $\mathbf{q}_1^\top \mathbf{x} = 0$, 则 $\mathbf{q}_1^\top A \mathbf{x} = (A \mathbf{q}_1)^\top \mathbf{x} = 0$, 故其正交补在 A 下不变, 且限制后的算子仍对称。归纳假设在该 $(d-1)$ 维子空间给出标准正交特征基; 与 $\mathbf{q}_1$ 合并即可组成 Q , 并得到式 (6.5)。■

谱定理中的 $Q^{-1} = Q^\top$, 所以变换到特征坐标不会改变欧氏长度。这正是对称特征分解数值行为较好的根本原因。若 $\mathbf{x} = \sum_{i=1}^d c_i \mathbf{q}_i$, 则

$$\mathbf{x}^\top A \mathbf{x} = \sum_{i=1}^d \lambda_i c_i^2. \quad (6.6)$$

因此, 对称矩阵为正定, 当且仅当全部特征值为正; 为半正定, 当且仅当全部特征值非负。复数域中的对应对象是 Hermitian 矩阵 $A^* = A$, 其中 $*$ 表示共轭转置; 把上面的转置换成共轭转置后, 谱定理与正定性的谱判据仍成立。一般复矩阵只满足普通转置对称并不足以保证这些结论。

回到式 (6.1)。它的 Gram 矩阵为

$$G_{\tilde{\epsilon}} = \mathbf{X}_{\tilde{\epsilon}}^\top \mathbf{X}_{\tilde{\epsilon}} = \begin{bmatrix} 1 & 1 \\ 1 & 1 + \tilde{\epsilon}^2 \end{bmatrix}.$$

由特征方程可得

$$\lambda_{\pm} = \frac{2 + \tilde{\epsilon}^2 \pm \sqrt{4 + \tilde{\epsilon}^4}}{2}. \quad (6.7)$$

当 $\tilde{\epsilon} \rightarrow 0$ 时, $\lambda_+ \rightarrow 2$ 而 $\lambda_- \sim \tilde{\epsilon}^2/2$ 。大特征值对应两列共同变化的方向, 小特征值对应近似相消的方向。后者正是系数可以大幅改变、预测却只改

变一点的原因。

6.1.3 Rayleigh 商把方向优化变成特征值问题

对实对称矩阵 $\mathbf{A}$ 和非零向量 $\mathbf{x}$ ，定义 **Rayleigh 商** (Rayleigh quotient)

$$R_{\mathbf{A}}(\mathbf{x}) = \frac{\mathbf{x}^{\top} \mathbf{A} \mathbf{x}}{\mathbf{x}^{\top} \mathbf{x}}. \quad (6.8)$$

它衡量二次型在方向 $\mathbf{x}$ 上的强度，并且不受 $\mathbf{x}$ 长度影响。

定理 6.2 Rayleigh–Ritz 变分原理 设实对称矩阵 $\mathbf{A}$ 的特征值按 $\lambda_1 \geq \dots \geq \lambda_d$ 排列，则

$$\lambda_d = \min_{\mathbf{x} \neq \mathbf{0}} R_{\mathbf{A}}(\mathbf{x}), \quad \lambda_1 = \max_{\mathbf{x} \neq \mathbf{0}} R_{\mathbf{A}}(\mathbf{x}). \quad (6.9)$$

等号分别在最小、最大特征值对应的非零特征向量上取得。

证明. 用谱定理写 $\mathbf{x} = \sum_i c_i \mathbf{q}_i$ 。由正交性，

$$R_{\mathbf{A}}(\mathbf{x}) = \frac{\sum_i \lambda_i c_i^2}{\sum_i c_i^2}.$$

右端是特征值的加权平均，权重 $c_i^2 / \sum_j c_j^2$ 非负且总和为 1，所以它位于 $[\lambda_d, \lambda_1]$ 内。取 $\mathbf{x} = \mathbf{q}_d$ 或 $\mathbf{q}_1$ 分别达到两端。 ■

Weyl 不等式需要逐个刻画中间特征值，而不只是谱的两个端点。为此使用 Courant–Fischer 极小极大原理的如下版本²。

定理 6.3 Courant–Fischer 极小极大原理 设实对称矩阵 $\mathbf{A} \in \mathbb{R}^{d \times d}$ 的特征值按 $\lambda_1 \geq \dots \geq \lambda_d$ 排列。对 $i = 1, \dots, d$,

$$\lambda_i = \max_{\dim S=i} \min_{\substack{\mathbf{x} \in S \\ \mathbf{x} \neq \mathbf{0}}} R_{\mathbf{A}}(\mathbf{x}) = \min_{\dim T=d-i+1} \max_{\substack{\mathbf{x} \in T \\ \mathbf{x} \neq \mathbf{0}}} R_{\mathbf{A}}(\mathbf{x}). \quad (6.10)$$

证明. 记 $\mathbf{A}$ 的一组标准正交特征向量为 $\mathbf{q}_1, \dots, \mathbf{q}_d$ ，并令 $E_i = \text{span}\{\mathbf{q}_1, \dots, \mathbf{q}_i\}$ ， $F_i = \text{span}\{\mathbf{q}_i, \dots, \mathbf{q}_d\}$ 。任意 i 维子空间 S 都与 F_i 有非零交向量；该向量的 Rayleigh 商不超过 λ_i ，所以第一个极值不超过 λ_i 。取 $S = E_i$ 时，其中每个非零向量的 Rayleigh 商都不小于 λ_i ，故等号成立。

同理，任意 $(d - i + 1)$ 维子空间 T 都与 E_i 有非零交向量；该向量的 Rayleigh 商不小于 λ_i ，所以第二个极值不小于 λ_i 。取 $T = F_i$ 时，其中每个非零向量的 Rayleigh 商都不超过 λ_i ，再次得到等号。 ■

² R. A. Horn, C. R. Johnson, *Matrix Analysis*, Cambridge University Press, 2013, 2nd ed.

这个定理不只是计算特征值的另一种写法。它说明最大特征向量是使二次型最强的单位方向，最小特征向量则是最弱方向。对 $\mathbf{G}_{\tilde{\varepsilon}} = \mathbf{X}_{\tilde{\varepsilon}}^{\top} \mathbf{X}_{\tilde{\varepsilon}}$,

$$R_{\mathbf{G}_{\tilde{\varepsilon}}}(\mathbf{z}) = \frac{\|\mathbf{X}_{\tilde{\varepsilon}} \mathbf{z}\|_2^2}{\|\mathbf{z}\|_2^2}.$$

因此 $\lambda_{\min}$ 直接量化 $\mathbf{X}_{\tilde{\varepsilon}}$ 对最弱系数方向的压缩程度，而不只是特征多项式的一个根。

只找一个最强方向还不足以决定应保留哪个 k 维子空间。令 $\mathbf{W} \in \mathbb{R}^{d \times k}$ 满足 $\mathbf{W}^{\top} \mathbf{W} = \mathbf{I}$ ，则子空间在二次型下保留的总强度为

$$\text{tr}(\mathbf{W}^{\top} \mathbf{A} \mathbf{W}).$$

把 $\mathbf{W}$ 的各列展开到 $\mathbf{A}$ 的正交特征基，并交换两次求和，可得

$$\max_{\mathbf{W}^{\top} \mathbf{W} = \mathbf{I}} \text{tr}(\mathbf{W}^{\top} \mathbf{A} \mathbf{W}) = \sum_{i=1}^k \lambda_i.$$

最大值由前 k 个特征向量张成的子空间达到。这是 Rayleigh–Ritz 原理的子空间形式：固定维数以后，应保留谱最大的方向。若边界处 $\lambda_k = \lambda_{k+1}$ ，最优值仍确定，但可以在对应重特征值子空间内更换标准正交基，甚至多个最优 k 维子空间；结论不能加强成唯一的特征向量选择。

6.1.4 广义特征值比较两个二次型

有时需要比较的不是 $\mathbf{x}^{\top} \mathbf{A} \mathbf{x}$ 与欧氏长度，而是两个二次型。设 $\mathbf{A}, \mathbf{B} \in \mathbb{R}^{d \times d}$ ，其中 $\mathbf{A}^{\top} = \mathbf{A}$ 且 $\mathbf{B}^{\top} = \mathbf{B} > \mathbf{0}$ 。**广义特征值问题** (generalized eigenvalue problem) 写作

$$\mathbf{A} \mathbf{v} = \lambda \mathbf{B} \mathbf{v}. \quad (6.11)$$

对应的广义 Rayleigh 商是

$$R_{\mathbf{A}, \mathbf{B}}(\mathbf{x}) = \frac{\mathbf{x}^{\top} \mathbf{A} \mathbf{x}}{\mathbf{x}^{\top} \mathbf{B} \mathbf{x}}.$$

由于 $\mathbf{B}$ 正定，存在可逆平方根 $\mathbf{B}^{1/2}$ 。令 $\mathbf{z} = \mathbf{B}^{1/2} \mathbf{x}$ ，便把广义 Rayleigh 商改写为

$$\frac{\mathbf{z}^{\top} \mathbf{B}^{-1/2} \mathbf{A} \mathbf{B}^{-1/2} \mathbf{z}}{\mathbf{z}^{\top} \mathbf{z}}.$$

同一变量变换还把广义特征方程化为

$$\mathbf{B}^{-1/2} \mathbf{A} \mathbf{B}^{-1/2} \mathbf{z} = \lambda \mathbf{z}.$$

中间矩阵是实对称矩阵，因此普通 Rayleigh–Ritz 结论可以直接应用。若广义特征值按 $\lambda_1 \geq \dots \geq \lambda_d$ 排列，则

$$\lambda_d = \min_{\mathbf{x}^\top \mathbf{B} \mathbf{x} = 1} \mathbf{x}^\top \mathbf{A} \mathbf{x}, \quad \lambda_1 = \max_{\mathbf{x}^\top \mathbf{B} \mathbf{x} = 1} \mathbf{x}^\top \mathbf{A} \mathbf{x}.$$

普通特征向量 $\mathbf{z}$ 通过 $\mathbf{x} = \mathbf{B}^{-1/2} \mathbf{z}$ 映回广义特征向量。这里不宜显式计算 $\mathbf{B}^{-1/2}$ ；实际算法通常用 Cholesky 分解完成等价变量变换。

$\mathbf{B}$ 只半正定时，分母可能为零，商在某些非零方向上没有定义； $\mathbf{B}$ 不定时，分母还会改变符号。此时广义特征值可能包含无穷特征值或复特征值，不能照搬正定情形的最值解释。条件“ $\mathbf{B}$ 正定”不是技术装饰，而是把第二个二次型变成合法长度的保证。

6.2 奇异值分解连接几何、低秩与最小二乘

6.2.1 任意矩阵都有正交的输入与输出方向

特征分解要求方阵，并且一般矩阵未必可对角化。对任意 $\mathbf{A} \in \mathbb{R}^{m \times n}$ ，**奇异值分解**（singular value decomposition, SVD）都给出

$$\mathbf{A} = \mathbf{U} \mathbf{\Sigma} \mathbf{V}^\top, \quad (6.12)$$

其中 $\mathbf{U} \in \mathbb{R}^{m \times m}$ 与 $\mathbf{V} \in \mathbb{R}^{n \times n}$ 是正交矩阵， $\mathbf{\Sigma} \in \mathbb{R}^{m \times n}$ 只有主对角线上可能非零。其非零对角元按

$$\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r > 0$$

排列，称为奇异值， $r = \text{rank}(\mathbf{A})$ 。上式是完整 SVD。只保留前 r 个非零奇异方向得到紧致 SVD $\mathbf{A} = \mathbf{U}_r \mathbf{\Sigma}_r \mathbf{V}_r^\top$ ，其中三个因子的形状依次为 $m \times r$ 、 $r \times r$ 与 $r \times n$ 。令 $q = \min(m, n)$ ，经济型或薄 SVD 则保留 q 个方向，三个因子的形状依次为 $m \times q$ 、 $q \times q$ 与 $q \times n$ ，其中仍可能包含零奇异值。写出采用哪一种形式可以避免把人为补齐的基向量误当成数据确定的方向。

这个分解可以从对称矩阵 $\mathbf{A}^\top \mathbf{A}$ 得到。它半正定，因而有标准正交特征向量 $\mathbf{v}_i$ 与非负特征值 σ_i^2 。对 $\sigma_i > 0$ ，定义 $\mathbf{u}_i = \mathbf{A} \mathbf{v}_i / \sigma_i$ ，则

$$\mathbf{u}_i^\top \mathbf{u}_j = \frac{\mathbf{v}_i^\top \mathbf{A}^\top \mathbf{A} \mathbf{v}_j}{\sigma_i \sigma_j} = \delta_{i,j}.$$

补全两侧的标准正交基便得到式 (6.12)。只保留非零奇异值及其对应向量，可写成紧致形式

$$\mathbf{A} = \sum_{i=1}^r \sigma_i \mathbf{u}_i \mathbf{v}_i^\top. \quad (6.13)$$

SVD 给出了明确的几何过程：先用 $\mathbf{V}^\top$ 旋转或反射输入坐标，再沿正交坐标轴分别按 σ_i 缩放，最后用 $\mathbf{U}$ 旋转或反射到输出空间。零奇异值对应被压到零的输入方向。由此立即得到

$$\text{null}(\mathbf{A}) = \text{span}\{\mathbf{v}_{r+1}, \dots, \mathbf{v}_n\}, \quad \text{range}(\mathbf{A}) = \text{span}\{\mathbf{u}_1, \dots, \mathbf{u}_r\}.$$

对贯穿本章的 $\mathbf{X}_{\tilde{\varepsilon}}$ ，奇异值满足 $\sigma_{\pm}^2 = \lambda_{\pm}$ ，其中 $\lambda_{\pm}$ 由式 (6.7) 给出。因此

$$\sigma_{\max} \rightarrow \sqrt{2}, \quad \sigma_{\min} \sim \frac{\tilde{\varepsilon}}{\sqrt{2}}.$$

近共线性不是“两个数字看起来接近”这么简单，而是存在一个单位系数方向，被设计矩阵缩小到约 $\tilde{\varepsilon}/\sqrt{2}$ 倍。当若干奇异值相等时，对应左右奇异向量可以同步旋转，单个向量并不唯一；由这些向量张成的左右奇异子空间才是不依赖基选择的对象。这个区别将在扰动分析中决定应该比较向量还是子空间。

6.2.2 截断 SVD 给出最佳低秩近似

若大部分奇异值很小，式 (6.13) 提示我们只保留前 k 项。定义

$$\mathbf{A}_k = \sum_{i=1}^k \sigma_i \mathbf{u}_i \mathbf{v}_i^\top, \quad k < r. \quad (6.14)$$

它的秩至多为 k 。问题在于，按奇异值截断是否真的比其他秩 k 矩阵更好³。

以下先局部约定矩阵 $\mathbf{M}$ 的**谱范数** (spectral norm) 为

$$\|\mathbf{M}\|_2 = \max_{\mathbf{x} \neq \mathbf{0}} \frac{\|\mathbf{M}\mathbf{x}\|_2}{\|\mathbf{x}\|_2} = \sigma_1(\mathbf{M}).$$

它衡量矩阵对单位输入的最大放大倍数；第 6.3 节将把它与其他矩阵范数统一比较。

³ C. Eckart, G. Young, *The Approximation of One Matrix by Another of Lower Rank* In *Psychometrika*, 1936, vol. 1, no. 3, pp. 211–218

定理 6.4 Eckart-Young-Mirsky 定理 设 $\mathbf{A}$ 的奇异值为 $\sigma_1 \geq \dots \geq \sigma_r > 0$ 。对任意 $0 \leq k < r$,

$$\min_{\text{rank}(\mathbf{B}) \leq k} \|\mathbf{A} - \mathbf{B}\|_2 = \sigma_{k+1}, \quad (6.15)$$

$$\min_{\text{rank}(\mathbf{B}) \leq k} \|\mathbf{A} - \mathbf{B}\|_F = \left(\sum_{i=k+1}^r \sigma_i^2 \right)^{1/2}. \quad (6.16)$$

两个最小值都由截断 SVD 矩阵 $\mathbf{A}_k$ 达到。

证明. 先证谱范数结论. 任取秩不超过 k 的 $\mathbf{B}$ 。子空间 $S = \text{span}\{\mathbf{v}_1, \dots, \mathbf{v}_{k+1}\}$ 维数为 $k+1$, 而 $\text{null}(\mathbf{B})$ 的维数至少为 $n-k$ 。维数公式保证 $S \cap \text{null}(\mathbf{B})$ 含有非零向量。取其中单位向量 $\mathbf{x} = \sum_{i=1}^{k+1} c_i \mathbf{v}_i$, 则

$$\|(\mathbf{A} - \mathbf{B})\mathbf{x}\|_2 = \|\mathbf{A}\mathbf{x}\|_2 = \left(\sum_{i=1}^{k+1} \sigma_i^2 c_i^2 \right)^{1/2} \geq \sigma_{k+1}.$$

所以任何候选 $\mathbf{B}$ 的误差都不小于 σ_{k+1} 。另一方面, $\mathbf{A} - \mathbf{A}_k = \sum_{i>k} \sigma_i \mathbf{u}_i \mathbf{v}_i^\top$, 其最大奇异值恰为 σ_{k+1} , 下界可以达到。

再证 Frobenius 范数结论。正交变换不改变 Frobenius 范数, 令 $\mathbf{C} = \mathbf{U}^\top \mathbf{B} \mathbf{V}$, 则

$$\|\mathbf{A} - \mathbf{B}\|_F^2 = \|\Sigma - \mathbf{C}\|_F^2.$$

把 $\mathbf{C}$ 的列空间投影记为 $\mathbf{P}$ 。由于 $\text{rank}(\mathbf{P}) \leq k$ 且 $\mathbf{P}\mathbf{C} = \mathbf{C}$,

$$\|\Sigma - \mathbf{C}\|_F^2 = \|(\mathbf{I} - \mathbf{P})\Sigma\|_F^2 + \|\mathbf{P}\Sigma - \mathbf{C}\|_F^2.$$

第二项非负。第一项在所有秩不超过 k 的正交投影中, 由投影到前 k 个坐标方向达到最小; 其值为 $\sum_{i>k} \sigma_i^2$ 。为看清这一步, 注意

$$\|\mathbf{P}\Sigma\|_F^2 = \sum_{i=1}^q \sigma_i^2 \|\mathbf{P}\mathbf{e}_i\|_2^2, \quad q = \min(m, n),$$

其中 $\mathbf{e}_i$ 是 $\mathbb{R}^m$ 中的坐标向量, 每个权重位于 $[0, 1]$ 。这些权重之和不超过 $\text{tr}(\mathbf{P}) \leq k$ 。要使保留能量最大, 应把权重给最大的 k 个 σ_i^2 。取 $\mathbf{C}$ 为截断后的 Σ 即可同时使第二项为零并达到下界。 ■

最佳近似未必唯一。对 Frobenius 范数, 若 $\sigma_k > \sigma_{k+1}$, 截断 SVD 给出的最佳矩阵唯一; 若 $\sigma_k = \sigma_{k+1}$, 可以在这个重奇异值对应的子空间内选择不同的 k 维保留方向, 得到多个同样最优的矩阵。谱范数只约束最大的剩余误差, 即使边界处存在严格间隙, 也可能允许其他最佳矩阵。定理保证两个误差最小值, 却不能在所有情形下唯一决定“应该保留哪一个方向”。

对 $\mathbf{X}_{\tilde{\epsilon}}$ 取 $k=1$, 谱范数误差正是 $\sigma_{\min} \sim \tilde{\epsilon}/\sqrt{2}$ 。当数据精度或噪声尺度大于这个量时, 把矩阵视为秩一近似可能比试图区分两个近共线方向更可靠。但截断会引入偏差; 若响应确实包含沿弱方向的稳定信号, 直接丢弃该方向也会损失信息。

6.2.3 主成分分析在固定维数下保留最大能量

设中心化数据矩阵 $\mathbf{X} \in \mathbb{R}^{n \times d}$ 的每一行是一个样本。希望用 k 维子空间表示数据, 可以选择具有标准正交列的 $\mathbf{V}_k \in \mathbb{R}^{d \times k}$, 并以 $\mathbf{X}\mathbf{V}_k\mathbf{V}_k^\top$ 重建数据。

重建误差为

$$\|\mathbf{X} - \mathbf{X}\mathbf{V}_k\mathbf{V}_k^\top\|_F^2.$$

由勾股关系, 这等于

$$\|\mathbf{X}\|_F^2 - \|\mathbf{X}\mathbf{V}_k\|_F^2.$$

若使用无偏样本协方差 $\mathbf{X}^\top\mathbf{X}/(n-1)$, 投影后各方向的样本方差之和正是 $\|\mathbf{X}\mathbf{V}_k\|_F^2/(n-1)$ 。所以最小化重建误差等价于最大化保留方差。Eckart-Young-Mirsky 定理表明, 应取 $\mathbf{X}$ 的前 k 个右奇异向量。这就是 **主成分分析** (principal component analysis, PCA) 的矩阵形式。

中心化条件不可省略。若不减去样本均值, 第一主方向可能主要指向数据整体离原点的位置, 而不是样本围绕均值变化最大的方向。特征量纲也会影响结果: 以米和毫米表示同一变量会改变协方差矩阵及主成分, 因此需要根据任务判断是否标准化。PCA 找到的是线性子空间, 也不保证最大方差方向就是最有预测价值的方向。

6.2.4 伪逆选择可解部分中的最小范数解

对紧致 SVD $\mathbf{A} = \mathbf{U}_r\boldsymbol{\Sigma}_r\mathbf{V}_r^\top$, 定义 **Moore-Penrose 伪逆** (Moore-Penrose pseudoinverse)

$$\mathbf{A}^\dagger = \mathbf{V}_r\boldsymbol{\Sigma}_r^{-1}\mathbf{U}_r^\top = \sum_{i=1}^r \frac{1}{\sigma_i} \mathbf{v}_i \mathbf{u}_i^\top. \quad (6.17)$$

它把输出在 $\text{range}(\mathbf{A})$ 上的分量沿非零奇异方向反向缩放, 并把正交于值域的分量丢弃。

伪逆也可以不借助某个特定 SVD 来刻画: $\mathbf{A}^\dagger$ 是唯一满足

$$\begin{aligned} \mathbf{A}\mathbf{A}^\dagger\mathbf{A} &= \mathbf{A}, & \mathbf{A}^\dagger\mathbf{A}\mathbf{A}^\dagger &= \mathbf{A}^\dagger, \\ (\mathbf{A}\mathbf{A}^\dagger)^\top &= \mathbf{A}\mathbf{A}^\dagger, & (\mathbf{A}^\dagger\mathbf{A})^\top &= \mathbf{A}^\dagger\mathbf{A} \end{aligned}$$

的矩阵。这四个 Moore-Penrose 等式分别保证反演在可解部分上一致, 并使输入、输出两侧得到正交投影。下面分别验证存在性与唯一性。

由紧致 SVD 直接得到

$$\mathbf{A}\mathbf{A}^\dagger = \mathbf{U}_r\mathbf{U}_r^\top =: \mathbf{P}_U, \quad \mathbf{A}^\dagger\mathbf{A} = \mathbf{V}_r\mathbf{V}_r^\top =: \mathbf{P}_V.$$

$\mathbf{P}_U$ 与 $\mathbf{P}_V$ 都是对称正交投影, 且 $\mathbf{P}_U\mathbf{A} = \mathbf{A}$ 、 $\mathbf{P}_V\mathbf{A}^\dagger = \mathbf{A}^\dagger$ 。于是逐项有

$$\mathbf{A}\mathbf{A}^\dagger\mathbf{A} = \mathbf{A}, \quad \mathbf{A}^\dagger\mathbf{A}\mathbf{A}^\dagger = \mathbf{A}^\dagger, \quad (\mathbf{A}\mathbf{A}^\dagger)^\top = \mathbf{A}\mathbf{A}^\dagger, \quad (\mathbf{A}^\dagger\mathbf{A})^\top = \mathbf{A}^\dagger\mathbf{A}.$$

再设 $\mathbf{X}$ 是任意满足四个等式的矩阵。 $\mathbf{A}\mathbf{X}$ 对称, 并由 $\mathbf{A}\mathbf{X}\mathbf{A} = \mathbf{A}$ 可知它幂等; 其值域包含于 $\text{range}(\mathbf{A})$, 同时对每个 $\mathbf{y} = \mathbf{A}\mathbf{z}$ 都有 $\mathbf{A}\mathbf{X}\mathbf{y} = \mathbf{A}\mathbf{z} = \mathbf{y}$ 。

因此 $\mathbf{AX}$ 是到 $\text{range}(\mathbf{A})$ 的正交投影, 即 $\mathbf{AX} = \mathbf{P}_U = \mathbf{AA}^\dagger$ 。类似地, $\mathbf{XA}$ 对称且幂等, 并且

$$\text{null}(\mathbf{XA}) = \text{null}(\mathbf{A}).$$

若 $\mathbf{XA}\mathbf{z} = \mathbf{0}$, 则 $\mathbf{Az} = \mathbf{AXAz} = \mathbf{0}$; 反向包含关系可直接由 $\mathbf{Az} = \mathbf{0}$ 得到。故 $\mathbf{XA}$ 是到 $\text{null}(\mathbf{A})^\perp = \text{range}(\mathbf{A}^\top)$ 的正交投影, 即 $\mathbf{XA} = \mathbf{P}_V = \mathbf{A}^\dagger\mathbf{A}$ 。最后利用第二个 Penrose 等式,

$$\mathbf{X} = \mathbf{XAX} = \mathbf{XAA}^\dagger = \mathbf{A}^\dagger\mathbf{AA}^\dagger = \mathbf{A}^\dagger.$$

因此, 四个 Penrose 等式唯一地确定伪逆。重奇异值对应的基即使发生旋转, 式 (6.17) 表示的线性映射仍不变。

定理 6.5 最小二乘与最小范数 给定 $\mathbf{A} \in \mathbb{R}^{m \times n}$ 与 $\mathbf{b} \in \mathbb{R}^m$, 向量 $\mathbf{x}^\dagger = \mathbf{A}^\dagger\mathbf{b}$ 满足:

1. 它最小化 $\|\mathbf{Ax} - \mathbf{b}\|_2$;
2. 在全部最小二乘解中, 它的欧氏范数最小;
3. 最小范数解是唯一的, 但一般的最小二乘解未必唯一。

证明. 把 $\mathbf{U}$ 补成 $\mathbb{R}^m$ 的标准正交基, 并将 $\mathbf{b}$ 唯一分解为

$$\mathbf{b} = \mathbf{U}_r\mathbf{c} + \mathbf{b}_\perp, \quad \mathbf{U}_r^\top\mathbf{b}_\perp = \mathbf{0}.$$

再把任意 $\mathbf{x}$ 写成 $\mathbf{x} = \mathbf{V}_r\mathbf{z} + \mathbf{x}_0$, 其中 $\mathbf{x}_0 \in \text{null}(\mathbf{A})$ 。正交性给出

$$\|\mathbf{Ax} - \mathbf{b}\|_2^2 = \|\Sigma_r\mathbf{z} - \mathbf{c}\|_2^2 + \|\mathbf{b}_\perp\|_2^2.$$

第二项不依赖 $\mathbf{x}$, 第一项在 $\mathbf{z} = \Sigma_r^{-1}\mathbf{c}$ 时达到零。因此全部最小二乘解为

$$\mathbf{x} = \mathbf{V}_r\Sigma_r^{-1}\mathbf{U}_r^\top\mathbf{b} + \mathbf{x}_0 = \mathbf{A}^\dagger\mathbf{b} + \mathbf{x}_0.$$

两项正交, 所以 $\|\mathbf{x}\|_2^2 = \|\mathbf{A}^\dagger\mathbf{b}\|_2^2 + \|\mathbf{x}_0\|_2^2$ 。范数仅在 $\mathbf{x}_0 = \mathbf{0}$ 时最小, 由此同时得到最小性与唯一性。■

若 $\mathbf{A}$ 列满秩, 则 $\mathbf{A}^\dagger = (\mathbf{A}^\top\mathbf{A})^{-1}\mathbf{A}^\top$; 若行满秩, 则 $\mathbf{A}^\dagger = \mathbf{A}^\top(\mathbf{AA}^\top)^{-1}$ 。这些公式适合推导, 却不意味着应在数值计算中显式形成逆矩阵。尤其是前一个公式会把条件数平方, 后文会说明它为何可能损失精度。

6.3 矩阵范数与有效秩

6.3.1 不同范数回答不同的误差问题

矩阵范数 (matrix norm) 把矩阵映射为非负标量, 并满足正定性、齐次性和三角不等式。若还满足 $\|\mathbf{AB}\| \leq \|\mathbf{A}\| \|\mathbf{B}\|$, 就称为次乘性范数。范数不是矩阵“大小”的唯一真值; 选用哪一种, 取决于希望控制逐元素误差、总体能量, 还是最坏输入方向。

最常用的三类范数为

$$\|\mathbf{A}\|_F = \left(\sum_{i,j} a_{i,j}^2 \right)^{1/2} = \left(\sum_i \sigma_i^2 \right)^{1/2}, \quad (6.18)$$

$$\|\mathbf{A}\|_2 = \max_{\mathbf{x} \neq \mathbf{0}} \frac{\|\mathbf{Ax}\|_2}{\|\mathbf{x}\|_2} = \sigma_1, \quad (6.19)$$

$$\|\mathbf{A}\|_* = \sum_i \sigma_i. \quad (6.20)$$

它们分别称为 Frobenius 范数、谱范数与核范数。Frobenius 范数汇总全部元素或全部奇异方向的平方能量; 谱范数只看放大最强的单位输入; 核范数把奇异值线性相加, 常被用作低秩的凸替代。

这三种范数属于同一个奇异值范数族。对 $p \geq 1$, 定义

$$\|\mathbf{A}\|_{S_p} = \left(\sum_i \sigma_i^p \right)^{1/p},$$

称为 **Schatten p 范数** (Schatten p -norm)。其中 $p = 1$ 给出核范数, $p = 2$ 给出 Frobenius 范数, 而 $p \rightarrow \infty$ 的极限给出谱范数。若 $0 < p < 1$, 同一公式仍能强调小奇异值的稀疏性, 但不满足三角不等式, 因而只是拟范数, 不能称为凸范数。

谱范数由向量欧氏范数诱导, 故 $\|\mathbf{Ax}\|_2 \leq \|\mathbf{A}\|_2 \|\mathbf{x}\|_2$ 。Frobenius 范数也次乘, 并有

$$\|\mathbf{AB}\|_F \leq \|\mathbf{A}\|_2 \|\mathbf{B}\|_F \leq \|\mathbf{A}\|_F \|\mathbf{B}\|_F. \quad (6.21)$$

第一步可以逐列应用谱范数定义再求和; 第二步使用 $\|\mathbf{A}\|_2 \leq \|\mathbf{A}\|_F$ 。

对秩为 r 的矩阵, 奇异值表达式还给出

$$\|\mathbf{A}\|_2 \leq \|\mathbf{A}\|_F \leq \sqrt{r} \|\mathbf{A}\|_2, \quad \|\mathbf{A}\|_F \leq \|\mathbf{A}\|_* \leq \sqrt{r} \|\mathbf{A}\|_F. \quad (6.22)$$

维数或秩增大时, 这些范数的比值可以随 $\sqrt{r}$ 增长。因此“范数都等价”在有限维空间中只表示它们诱导相同的收敛概念, 不表示误差界中的常数可以忽略。

6.3.2 诱导范数保留输入输出的语义

对任意向量范数 $\|\cdot\|$ ，相应的诱导矩阵范数定义为

$$\|\mathbf{A}\| = \max_{\mathbf{x} \neq \mathbf{0}} \frac{\|\mathbf{A}\mathbf{x}\|}{\|\mathbf{x}\|}.$$

除谱范数外，常见的还有

$$\|\mathbf{A}\|_1 = \max_j \sum_i |a_{i,j}|, \quad \|\mathbf{A}\|_\infty = \max_i \sum_j |a_{i,j}|.$$

前者是最大绝对列和，后者是最大绝对行和。若输入误差用 ℓ_1 范数衡量， $\|\mathbf{A}\|_1$ 控制最坏输出放大；若关心每个坐标的最大误差，则 $\|\mathbf{A}\|_\infty$ 更自然。

逐元素最大值 $\max_{i,j} |a_{i,j}|$ 不是由向量 ℓ_∞ 范数诱导的上述矩阵范数；使用“最大范数”一词时必须写清定义。

混合范数 (mixed norm) 则先在一组坐标内聚合，再在组之间聚合。例如

$$\|\mathbf{A}\|_{2,1} = \sum_{i=1}^m \left(\sum_{j=1}^n a_{i,j}^2 \right)^{1/2}$$

先计算每一行的欧氏范数，再把各行结果相加，因而控制坐标分组而不只是奇异谱。也有文献用 $\|\cdot\|_{2,1}$ 表示按列分组的版本，所以使用时应同时说明分组方向。这类范数依赖给定坐标中的行列分组，不像 Schatten 范数那样只由奇异值决定。

6.3.3 有效秩描述奇异值能量是否集中

代数秩把非零与零严格分开，却对数值精度极其敏感。任意微小的扰动都可能把零奇异值变成非零值。若想描述一个矩阵“实际上有多少个重要方向”，需要连续的尺度。

对非零矩阵，一种常用定义是**稳定秩** (stable rank)

$$r_{\text{stable}}(\mathbf{A}) = \frac{\|\mathbf{A}\|_F^2}{\|\mathbf{A}\|_2^2} = \frac{\sum_i \sigma_i^2}{\sigma_1^2}. \quad (6.23)$$

它位于 $[1, \text{rank}(\mathbf{A})]$ 内。所有非零奇异值相等时，它等于代数秩；能量集中在第一个奇异值时，它接近 1。零矩阵会使定义式成为 $0/0$ ，通常另约定 $r_{\text{stable}}(\mathbf{0}) = 0$ ，而不是把区间 $[1, \text{rank}(\mathbf{A})]$ 机械用于零矩阵。

稳定秩是常用的**有效秩** (effective rank) 之一。文献中还有基于归一化奇异值谱熵的有效秩，因此使用这个名称时必须同时给出公式。本节不把它称为“有效维数”：第 4 章的核有效维度 $d_{\text{eff}}(\lambda)$ 按正则化尺度 λ 给每个核谱方向加权，描述的是函数空间在该尺度下的复杂度；稳定秩不含正则

化尺度, 比较的是一个有限矩阵的总平方奇异值能量与最大平方奇异值。二者都能连续地计算谱方向的贡献, 但对象和用途不同。

对 $\mathbf{X}_{\tilde{\varepsilon}}$,

$$r_{\text{stable}}(\mathbf{X}_{\tilde{\varepsilon}}) = \frac{\sigma_{\max}^2 + \sigma_{\min}^2}{\sigma_{\max}^2} = 1 + \frac{\lambda_-}{\lambda_+} \longrightarrow 1.$$

它在 $\tilde{\varepsilon} > 0$ 时代数秩始终为 2, 但稳定秩连续地反映出矩阵越来越接近秩一。有效秩适合描述尺度, 不会自动给出截断阈值; 阈值还应结合噪声、任务损失与计算预算。

矩阵乘积的幅度可以逐层控制。若维度相容, 则

$$\|\mathbf{A}_L \cdots \mathbf{A}_1\|_2 \leq \prod_{\ell=1}^L \|\mathbf{A}_{\ell}\|_2.$$

这给出深层线性映射或 Jacobian 乘积的最坏方向上界, 但每一步取到最坏方向通常要求这些方向能够对齐, 所以上界未必紧。稳定秩也不能沿乘积简单相乘, 更不等于截断以后实际保留的整数方向数。

6.4 矩阵函数与结构化运算

6.4.1 从标量函数到矩阵函数

若对角化矩阵 $\mathbf{A} = \mathbf{V}\mathbf{\Lambda}\mathbf{V}^{-1}$ 的谱位于标量函数 f 的定义域内, 可以定义

$$f(\mathbf{A}) = \mathbf{V}f(\mathbf{\Lambda})\mathbf{V}^{-1}, \quad f(\mathbf{\Lambda}) = \text{diag}(f(\lambda_1), \dots, f(\lambda_d)). \quad (6.24)$$

白话地说, 矩阵函数在每个特征方向上应用同一个标量函数。对称正定矩阵因而有唯一的对称正定平方根

$$\mathbf{A}^{1/2} = \mathbf{Q} \text{diag}(\sqrt{\lambda_i}) \mathbf{Q}^{\top},$$

并可定义 $\mathbf{A}^{-1/2} = \mathbf{Q} \text{diag}(\lambda_i^{-1/2}) \mathbf{Q}^{\top}$ 、 $\log \mathbf{A} = \mathbf{Q} \text{diag}(\log \lambda_i) \mathbf{Q}^{\top}$ 与任意实数次幂。严格正定保证这些表达都为实矩阵, 也保证正定平方根唯一; 半正定矩阵仍有唯一半正定平方根, 但零特征值使逆平方根和实对数不再按上述公式定义。

一般方阵未必可对角化。复 Schur 分解保证存在酉矩阵 $\mathbf{Q}$ 和上三角矩阵 $\mathbf{T}$ 使

$$\mathbf{A} = \mathbf{Q}\mathbf{T}\mathbf{Q}^*. \quad (6.25)$$

$\mathbf{T}$ 的对角元就是 $\mathbf{A}$ 的特征值。Schur 形式避免使用可能病态的特征向量矩阵, 许多数值矩阵函数算法会先得到 $\mathbf{T}$, 在三角矩阵上计算 $f(\mathbf{T})$, 再变换回来。若只在实数中计算, 也可以使用由 1×1 与 2×2 对角块组成的实 Schur 形式。

另一条定义路线来自幂级数。若 $f(z) = \sum_{k=0}^{\infty} a_k z^k$ 在包含矩阵谱的区域收敛, 则

$$f(\mathbf{A}) = \sum_{k=0}^{\infty} a_k \mathbf{A}^k.$$

例如矩阵指数为

$$\exp(\mathbf{A}) = \sum_{k=0}^{\infty} \frac{\mathbf{A}^k}{k!}. \quad (6.26)$$

级数对每个有限矩阵都收敛。若线性常微分方程满足 $\mathbf{x}'(t) = \mathbf{A}\mathbf{x}(t)$ 且 $\mathbf{x}(0) = \mathbf{x}_0$, 则 $\mathbf{x}(t) = \exp(t\mathbf{A})\mathbf{x}_0$ 。直接对级数逐项求导可验证这个结论。

幂级数定义也覆盖不可对角化矩阵。复数域上的 Jordan 分解把任意方阵相似变换为若干 Jordan 块, 每个块可写成 $\mathbf{J} = \lambda\mathbf{I} + \mathbf{N}$, 其中 $\mathbf{N}$ 只有超对角线为 1, 且对块大小 s 满足 $\mathbf{N}^s = \mathbf{0}$ 。因为 $\lambda\mathbf{I}$ 与 $\mathbf{N}$ 交换,

$$\exp(t\mathbf{J}) = e^{\lambda t} \sum_{j=0}^{s-1} \frac{t^j}{j!} \mathbf{N}^j.$$

求和在 $s-1$ 次终止, 说明不可对角化块除了指数因子, 还会产生关于 t 的多项式因子。这里使用 Jordan 形式是为了解释结构, 不表示数值计算应显式求一个可能病态的 Jordan 基。第 16 章判断线性系统稳定性时, 会同时检查指数衰减和这些多项式因子。

矩阵乘法通常不交换, 所以标量恒等式不能机械搬来。例如一般只有在 $\mathbf{AB} = \mathbf{BA}$ 时才有

$$\exp(\mathbf{A} + \mathbf{B}) = \exp(\mathbf{A}) \exp(\mathbf{B}).$$

引入标量 t 并展开到二阶, 可以直接看出差异:

$$\begin{aligned} \exp(t(\mathbf{A} + \mathbf{B})) &= \mathbf{I} + t(\mathbf{A} + \mathbf{B}) + \frac{t^2}{2}(\mathbf{A}^2 + \mathbf{AB} + \mathbf{BA} + \mathbf{B}^2) + O(t^3), \\ \exp(t\mathbf{A}) \exp(t\mathbf{B}) &= \mathbf{I} + t(\mathbf{A} + \mathbf{B}) + t^2 \left(\frac{\mathbf{A}^2}{2} + \mathbf{AB} + \frac{\mathbf{B}^2}{2} \right) + O(t^3). \end{aligned}$$

左端的二阶交叉项为 $(\mathbf{AB} + \mathbf{BA})/2$, 右端则为 $\mathbf{AB}$; 两者之差为 $(\mathbf{BA} - \mathbf{AB})/2$ 。非交换性正是矩阵微积分和结构化算法中必须持续检查的边界。

6.4.2 分块消元产生 Schur 补

分块矩阵并不只是记号上的拼接; 消去一组变量以后, 另一组变量会获得一个新的有效系数。设

$$\mathbf{M} = \begin{bmatrix} \mathbf{A} & \mathbf{B} \\ \mathbf{C} & \mathbf{D} \end{bmatrix},$$

其中 $\mathbf{A}$ 为可逆方阵。对块行做与高斯消元相同的操作,

$$\begin{bmatrix} \mathbf{I} & \mathbf{0} \\ -\mathbf{CA}^{-1} & \mathbf{I} \end{bmatrix} \begin{bmatrix} \mathbf{A} & \mathbf{B} \\ \mathbf{C} & \mathbf{D} \end{bmatrix} = \begin{bmatrix} \mathbf{A} & \mathbf{B} \\ \mathbf{0} & \mathbf{S} \end{bmatrix}, \quad \mathbf{S} = \mathbf{D} - \mathbf{CA}^{-1}\mathbf{B}. \quad (6.27)$$

$\mathbf{S}$ 称为 $\mathbf{A}$ 在 $\mathbf{M}$ 中的 **Schur 补** (Schur complement)。若右端按相同方式分块, 先由第一组方程表达被消去的变量, 再代入第二组方程, 得到的正是以 $\mathbf{S}$ 为系数的约化方程。因此 Schur 补记录了消去第一组变量后, 第二组变量之间剩余的直接作用。

当 $\mathbf{M}$ 对称且 $\mathbf{C} = \mathbf{B}^\top$ 时, 正定性也能沿这次消元传递。对任意 $\mathbf{x}, \mathbf{y}$, 配方得到

$$\begin{bmatrix} \mathbf{x} \\ \mathbf{y} \end{bmatrix}^\top \mathbf{M} \begin{bmatrix} \mathbf{x} \\ \mathbf{y} \end{bmatrix} = (\mathbf{x} + \mathbf{A}^{-1}\mathbf{B}\mathbf{y})^\top \mathbf{A} (\mathbf{x} + \mathbf{A}^{-1}\mathbf{B}\mathbf{y}) + \mathbf{y}^\top \mathbf{S} \mathbf{y}.$$

由此可见, 在 $\mathbf{A} > \mathbf{0}$ 的前提下,

$$\mathbf{M} > \mathbf{0} \iff \mathbf{S} = \mathbf{D} - \mathbf{B}^\top \mathbf{A}^{-1} \mathbf{B} > \mathbf{0}. \quad (6.28)$$

半正定情形不能只把两个严格不等号机械改成非严格不等号, 因为 $\mathbf{A}$ 可能不可逆; 此时需要伪逆以及相应的值域条件。

若 $\mathbf{S}$ 也可逆, 依次解两个三角分块系统可得

$$\mathbf{M}^{-1} = \begin{bmatrix} \mathbf{A}^{-1} + \mathbf{A}^{-1}\mathbf{B}\mathbf{S}^{-1}\mathbf{C}\mathbf{A}^{-1} & -\mathbf{A}^{-1}\mathbf{B}\mathbf{S}^{-1} \\ -\mathbf{S}^{-1}\mathbf{C}\mathbf{A}^{-1} & \mathbf{S}^{-1} \end{bmatrix}. \quad (6.29)$$

式 (6.27) 至 (6.29) 将在第 8 章用于条件高斯的均值与协方差, 并在第 16 章用于滤波和状态估计。这些公式适合推导结构; 实际计算仍应通过分解和线性求解应用 $\mathbf{A}^{-1}$ 与 $\mathbf{S}^{-1}$, 而不是显式形成逆矩阵。

6.4.3 低秩更新不必重新求逆

设 $\mathbf{A} \in \mathbb{R}^{n \times n}$ 可逆, $\mathbf{U}, \mathbf{V} \in \mathbb{R}^{n \times k}$, $\mathbf{C} \in \mathbb{R}^{k \times k}$ 可逆。若 $\mathbf{C}^{-1} + \mathbf{V}^\top \mathbf{A}^{-1} \mathbf{U}$ 也可逆, 则 **Woodbury 恒等式**给出

$$(\mathbf{A} + \mathbf{UCV}^\top)^{-1} = \mathbf{A}^{-1} - \mathbf{A}^{-1} \mathbf{U} (\mathbf{C}^{-1} + \mathbf{V}^\top \mathbf{A}^{-1} \mathbf{U})^{-1} \mathbf{V}^\top \mathbf{A}^{-1}. \quad (6.30)$$

右侧把一个 n 维更新问题缩成 k 维求解。记括号内的小矩阵为 $\mathbf{S}$, 将右侧与 $\mathbf{A} + \mathbf{UCV}^\top$ 相乘, 并代入 $\mathbf{I} - \mathbf{S}^{-1} \mathbf{V}^\top \mathbf{A}^{-1} \mathbf{U} = \mathbf{S}^{-1} \mathbf{C}^{-1}$, 即可验证乘积为单位矩阵。它也可由分块矩阵 $\begin{bmatrix} \mathbf{A} & \mathbf{U} \\ -\mathbf{V}^\top & \mathbf{C}^{-1} \end{bmatrix}$ 按两种顺序消元得到: 消去 $\mathbf{A}$ 产生小 Schur 补 $\mathbf{C}^{-1} + \mathbf{V}^\top \mathbf{A}^{-1} \mathbf{U}$, 消去 $\mathbf{C}^{-1}$ 则产生更新后的大矩阵 $\mathbf{A} + \mathbf{UCV}^\top$ 。这说明 Woodbury 恒等式本质上是在比较同一个分块系统的两种消元次序。

当 $k = 1$ 且 $C = 1$ 时, 该式退化为 Sherman–Morrison 公式。它常用于样本增删、低秩协方差更新和带低秩修正的线性系统。但公式出现 A^{-1} 不表示实现时应先形成逆矩阵; 更稳定的做法是复用 A 的分解, 通过线性求解得到 $A^{-1}U$ 。若中间的小矩阵接近奇异, 更新后的大矩阵也接近奇异, 公式本身不会消除这个敏感性。

不含 C 的常用形式更直接体现辅助变量消元。要解 $(A + UV^T)x = b$, 可先令 $z = V^T x$ 。由 $x = A^{-1}(b - Uz)$ 得到

$$(I + V^T A^{-1} U)z = V^T A^{-1} b.$$

因此只需假设 A 与 $I + V^T A^{-1} U$ 可逆, 不需要给通常为长方形的 U 或 V 假定不存在的逆。

例如取 $A = \text{diag}(2, 3)$ 、 $u = v = (1, 1)^T$ 和 $b = (1, 0)^T$ 。直接求解 $\begin{bmatrix} 3 & 1 \\ 1 & 4 \end{bmatrix} x = b$ 得到 $x = (4/11, -1/11)^T$ 。辅助变量公式中的小系统只有一个标量,

$$1 + u^T A^{-1} u = 1 + \frac{1}{2} + \frac{1}{3} = \frac{11}{6}.$$

代入 Sherman–Morrison 公式也得到

$$x = A^{-1}b - A^{-1}u \left(1 + u^T A^{-1}u\right)^{-1} u^T A^{-1}b = \begin{bmatrix} 4/11 \\ -1/11 \end{bmatrix}.$$

这个二阶算例展示的是计算组织方式; 规模收益只有在更新秩远小于原矩阵维数且原分解可以复用时才出现。

6.4.4 Kronecker 积表达可分离结构

沿用式 (5.23) 中的 Kronecker 积定义。给定 $A \in \mathbb{R}^{m \times n}$ 与 $B \in \mathbb{R}^{p \times q}$, $A \otimes B$ 的维度是 $mp \times nq$ 。只要各乘积维度相容, 就有

$$(A \otimes B)(C \otimes D) = (AC) \otimes (BD). \quad (6.31)$$

若 A 与 B 均为可逆方阵, 还可得到 $(A \otimes B)^{-1} = A^{-1} \otimes B^{-1}$ 。

把矩阵按列堆叠为向量的运算记为 vec 。逐列检查可得

$$\text{vec}(AXB) = (B^T \otimes A) \text{vec}(X). \quad (6.32)$$

若 $A \in \mathbb{R}^{p \times m}$ 、 $X \in \mathbb{R}^{m \times n}$ 、 $B \in \mathbb{R}^{n \times q}$, 则等式左侧和右侧都在 $\mathbb{R}^{pq}$ 中。更具体地, AXB 的第 (i, j) 个元素为

$$\sum_{\ell=1}^m \sum_{k=1}^n a_{i,\ell} x_{\ell,k} b_{k,j}.$$

按列堆叠后, 这个元素位于索引 $i + (j - 1)p$; 展开 $(\mathbf{B}^\top \otimes \mathbf{A})\text{vec}(\mathbf{X})$ 在同一索引的分量, 得到完全相同的二重求和。这既证明了恒等式, 也解释了为什么右侧是 $\mathbf{B}^\top \otimes \mathbf{A}$ 而不是两个因子的其他次序。这个恒等式把矩阵方程转成线性方程, 也揭示了多维网格与可分离协方差中的结构。实际计算通常不应显式构造巨大的 Kronecker 矩阵; 利用左右乘法实现同一个线性算子, 可以显著减少存储和运算量。

6.4.5 极分解分开旋转与伸缩

任意 $\mathbf{A} \in \mathbb{R}^{m \times n}$ 都有 **极分解** (polar decomposition)

$$\mathbf{A} = \mathbf{Q}\mathbf{H}, \quad \mathbf{H} = (\mathbf{A}^\top \mathbf{A})^{1/2}, \quad (6.33)$$

其中 $\mathbf{H}$ 半正定, $\mathbf{Q}$ 是部分等距映射。用 SVD 可取 $\mathbf{H} = \mathbf{V}(\boldsymbol{\Sigma}^\top \boldsymbol{\Sigma})^{1/2} \mathbf{V}^\top$; 更直接地, 在紧致 SVD 下, $\mathbf{H} = \mathbf{V}_r \boldsymbol{\Sigma}_r \mathbf{V}_r^\top$, 并在零空间上取零, $\mathbf{Q} = \mathbf{U}_r \mathbf{V}_r^\top \in \mathbb{R}^{m \times n}$ 。此时

$$\mathbf{Q}^\top \mathbf{Q} = \mathbf{V}_r \mathbf{V}_r^\top = \mathbf{P}_{\text{null}(\mathbf{A})^\perp}, \quad \mathbf{Q}\mathbf{Q}^\top = \mathbf{U}_r \mathbf{U}_r^\top = \mathbf{P}_{\text{range}(\mathbf{A})}.$$

因此“部分等距”是指 $\mathbf{Q}$ 在 $\text{null}(\mathbf{A})^\perp$ 上保持欧氏长度, 并把该子空间等距映到 $\text{range}(\mathbf{A})$; 它把 $\text{null}(\mathbf{A})$ 中的方向映为零。

当 $\mathbf{A}$ 为可逆方阵时, $\mathbf{Q}$ 正交且分解唯一。矩阵秩亏时, $\mathbf{H}$ 仍唯一, 要求 $\text{null}(\mathbf{Q}) = \text{null}(\mathbf{A})$ 时, 上式给出的部分等距因子也唯一; 若维数允许, 并进一步把它延拓为在零空间上仍保持长度的等距映射, 则原矩阵没有规定这些零方向应映到哪里, 延拓可能不唯一。极分解把矩阵的角度变化与非负伸缩分开, 在正交约束优化、形状对齐和迭代矩阵正交化中很有用。

6.4.6 矩阵函数的 Fréchet 导数保留非交换信息

第 2 章已经从乘积恒等式推导了逆矩阵的微分, 并用 Jacobi 公式推导了 $\log \det \mathbf{A}$ 的微分。本节关心更一般的问题: 当输入矩阵沿 $\mathbf{E}$ 变化时, 矩阵函数 $f(\mathbf{A})$ 的一阶变化是什么。若存在线性映射 $L_f(\mathbf{A}, \cdot)$ 使

$$f(\mathbf{A} + \mathbf{E}) - f(\mathbf{A}) = L_f(\mathbf{A}, \mathbf{E}) + o(\|\mathbf{E}\|), \quad (6.34)$$

就称 $L_f(\mathbf{A}, \mathbf{E})$ 为 f 在 $\mathbf{A}$ 处沿 $\mathbf{E}$ 的 **Fréchet 导数** (Fréchet derivative)。它对扰动 $\mathbf{E}$ 线性, 却通常不是简单的 $f'(\mathbf{A})\mathbf{E}$ 。

对称矩阵 $\mathbf{A} = \mathbf{Q} \text{diag}(\lambda_i) \mathbf{Q}^\top$ 及对称扰动 $\mathbf{E}$ 给出一个直接表达。定义一

阶差商矩阵

$$\mathbf{F}_{i,j}^{[1]} = \begin{cases} \frac{f(\lambda_i) - f(\lambda_j)}{\lambda_i - \lambda_j}, & \lambda_i \neq \lambda_j, \\ f'(\lambda_i), & \lambda_i = \lambda_j. \end{cases}$$

在 f 对相应谱区间连续可微等保证矩阵函数可微的条件下,

$$L_f(\mathbf{A}, \mathbf{E}) = \mathbf{Q} \left(\mathbf{F}^{[1]} \odot (\mathbf{Q}^\top \mathbf{E} \mathbf{Q}) \right) \mathbf{Q}^\top, \quad (6.35)$$

其中 $\odot$ 表示逐元素乘法。对角项使用标量导数, 非对角项却由两个不同特征值之间的差商控制; 这正是标量口诀遗漏的非交换信息。当 $\mathbf{A}\mathbf{E} = \mathbf{E}\mathbf{A}$ 时, 扰动在 $\mathbf{A}$ 的不同谱块之间没有交叉, 式 (6.35) 可以化为熟悉的 $L_f(\mathbf{A}, \mathbf{E}) = f'(\mathbf{A})\mathbf{E}$ 。若二者不交换, 一般不能作此简化; 不过对仿射函数等特殊情形, 等式仍可能成立, 所以交换性是这里的充分条件而非必要条件。

矩阵指数把这条边界表现得很清楚:

$$L_{\exp}(\mathbf{A}, \mathbf{E}) = \int_0^1 \exp((1-s)\mathbf{A})\mathbf{E} \exp(s\mathbf{A}) \, ds. \quad (6.36)$$

若 $\mathbf{A}$ 与 $\mathbf{E}$ 交换, 积分才等于 $\exp(\mathbf{A})\mathbf{E}$; 一般情形必须保留 $\mathbf{E}$ 两侧因子的次序。逆矩阵微分中的 $-\mathbf{A}^{-1}\mathbf{E}\mathbf{A}^{-1}$ 是同一现象的特例, 而标量函数 $\log \det \mathbf{A}$ 输出一个数, 其迹表达式已由第 2 章处理, 无须在这里重复推导。

平方根的微分给出另一个不宜交换次序的例子。设 $\mathbf{A} > \mathbf{0}$ 且 $\mathbf{S} = \mathbf{A}^{1/2}$ 。沿对称扰动 $\mathbf{E}$ 对恒等式 $\mathbf{S}^2 = \mathbf{A}$ 求一阶变化, 若 $\mathbf{Z} = L_{\sqrt{\cdot}}(\mathbf{A}, \mathbf{E})$, 则 $\mathbf{Z}$ 满足

$$\mathbf{SZ} + \mathbf{ZS} = \mathbf{E}.$$

这是一类 **Sylvester 方程** (Sylvester equation)。在 $\mathbf{S} = \mathbf{Q} \operatorname{diag}(s_i) \mathbf{Q}^\top$ 的特征基中, 记 $\hat{\mathbf{Z}} = \mathbf{Q}^\top \mathbf{Z} \mathbf{Q}$ 与 $\hat{\mathbf{E}} = \mathbf{Q}^\top \mathbf{E} \mathbf{Q}$, 逐项便有

$$\hat{z}_{i,j} = \frac{\hat{e}_{i,j}}{s_i + s_j}.$$

正定性保证 $s_i + s_j > 0$, 所以解唯一。只有在 $\mathbf{A}$ 与 $\mathbf{E}$ 交换时, 非对角耦合消失, 结果才可简化为标量式 $\mathbf{Z} = \frac{1}{2}\mathbf{A}^{-1/2}\mathbf{E}$; 一般情形中把 $\mathbf{A}^{-1/2}$ 随意放到扰动一侧都会丢失次序信息。

6.5 条件数与扰动解释何时难以求准

6.5.1 条件数属于问题，而不是某个算法

对可逆方阵 $\mathbf{A}$ ，相对于诱导范数的 **条件数** (condition number) 定义为

$$\kappa(\mathbf{A}) = \|\mathbf{A}\| \|\mathbf{A}^{-1}\|. \quad (6.37)$$

在谱范数下，

$$\kappa_2(\mathbf{A}) = \frac{\sigma_{\max}(\mathbf{A})}{\sigma_{\min}(\mathbf{A})}. \quad (6.38)$$

它比较最强与最弱的方向性缩放。正交矩阵的条件数为 1；矩阵接近奇异时， $\sigma_{\min}$ 接近零，条件数变大。秩亏矩阵通常约定条件数为无穷大。对满秩长方矩阵 $\mathbf{A} \in \mathbb{R}^{m \times n}$ ，常把谱条件数定义为 $\kappa_2(\mathbf{A}) = \sigma_1/\sigma_q$ ，其中 $q = \min(m, n)$ 且 $\sigma_q > 0$ 。若矩阵秩亏，涉及反演或最小二乘问题在任意输入扰动下的条件数仍通常约定为无穷大；但固定该矩阵以后，伪逆作为线性映射仍有有限范数，这两种口径需要区分。

只扰动右端时，令 $\mathbf{b} \neq \mathbf{0}$ ，并考虑 $\mathbf{Ax} = \mathbf{b}$ 和 $\mathbf{A}(\mathbf{x} + \Delta\mathbf{x}) = \mathbf{b} + \Delta\mathbf{b}$ 。两式相减得到 $\Delta\mathbf{x} = \mathbf{A}^{-1}\Delta\mathbf{b}$ ，于是

$$\frac{\|\Delta\mathbf{x}\|}{\|\mathbf{x}\|} \leq \kappa(\mathbf{A}) \frac{\|\Delta\mathbf{b}\|}{\|\mathbf{b}\|}.$$

这里用到了 $\|\mathbf{b}\| = \|\mathbf{Ax}\| \leq \|\mathbf{A}\|\|\mathbf{x}\|$ 。该不等式是最坏方向的上界，并不表示每个扰动都会被放大 $\kappa(\mathbf{A})$ 倍。

对 $\mathbf{X}_{\bar{\varepsilon}}$,

$$\kappa_2(\mathbf{X}_{\bar{\varepsilon}}) = \sqrt{\frac{\lambda_+}{\lambda_-}} \sim \frac{2}{\bar{\varepsilon}}.$$

式 (6.2) 选择的 $\Delta\mathbf{y} = (0, \eta)^\top$ 含有弱左奇异方向上的分量，因此系数变化达到 $1/\bar{\varepsilon}$ 量级。这不是求解器制造的不稳定，而是从响应反推两个近共线系数本来就敏感。

6.5.2 同时扰动矩阵与右端

设 $\mathbf{A} \in \mathbb{R}^{d \times d}$ 可逆、 $\mathbf{b} \neq \mathbf{0}$ ，原系统为 $\mathbf{Ax} = \mathbf{b}$ ，其唯一解为 $\mathbf{x}$ 。扰动后为

$$(\mathbf{A} + \Delta\mathbf{A})(\mathbf{x} + \Delta\mathbf{x}) = \mathbf{b} + \Delta\mathbf{b}.$$

整理可得

$$\mathbf{A}\Delta\mathbf{x} = \Delta\mathbf{b} - \Delta\mathbf{A}\mathbf{x} - \Delta\mathbf{A}\Delta\mathbf{x}.$$

若 $\|\mathbf{A}^{-1}\|\|\Delta\mathbf{A}\| < 1$ ，把最后一项移到左侧并用范数界控制，得到

$$\frac{\|\Delta\mathbf{x}\|}{\|\mathbf{x}\|} \leq \frac{\kappa(\mathbf{A})}{1 - \kappa(\mathbf{A})\|\Delta\mathbf{A}\|/\|\mathbf{A}\|} \left(\frac{\|\Delta\mathbf{A}\|}{\|\mathbf{A}\|} + \frac{\|\Delta\mathbf{b}\|}{\|\mathbf{b}\|} \right). \quad (6.39)$$

分母条件保证扰动还没有把系统推过奇异边界。若条件不满足，这个上界失效，并不等于扰动后的矩阵一定奇异；它只表示该推导不能再保证稳定。

正规方程会恶化近共线问题。列满秩矩阵满足

$$\kappa_2(\mathbf{A}^\top \mathbf{A}) = \kappa_2(\mathbf{A})^2, \quad (6.40)$$

因为 $\mathbf{A}^\top \mathbf{A}$ 的最大、最小特征值分别是 $\sigma_{\max}^2$ 与 $\sigma_{\min}^2$ 。对 $\mathbf{X}_{\bar{\epsilon}}$ ，条件数从 $2/\bar{\epsilon}$ 量级变为 $4/\bar{\epsilon}^2$ 量级。这就是数值计算中更偏好 QR 或 SVD 直接处理最小二乘问题的原因。

6.5.3 系数不稳定不等于拟合值不稳定

设 $\mathbf{X} \in \mathbb{R}^{n \times d}$ ，最小二乘拟合值为

$$\hat{\mathbf{y}} = \mathbf{X}\mathbf{X}^\dagger \mathbf{y}.$$

矩阵 $\mathbf{P}_\mathbf{X} = \mathbf{X}\mathbf{X}^\dagger$ 是到 $\text{range}(\mathbf{X})$ 的正交投影，所以 $\|\mathbf{P}_\mathbf{X}\|_2 \leq 1$ 。当设计矩阵固定而只扰动响应时，

$$\|\Delta \hat{\mathbf{y}}\|_2 = \|\mathbf{P}_\mathbf{X} \Delta \mathbf{y}\|_2 \leq \|\Delta \mathbf{y}\|_2.$$

相反，最小范数系数的变化 $\Delta \hat{\boldsymbol{\beta}} = \mathbf{X}^\dagger \Delta \mathbf{y}$ 由 $\|\mathbf{X}^\dagger\|_2$ 控制。若 $r = \text{rank}(\mathbf{X}) > 0$ ，则

$$\|\mathbf{X}^\dagger\|_2 = \frac{1}{\sigma_r},$$

其中 σ_r 是最小正奇异值；零奇异方向由伪逆置零，并不会按 $1/0$ 放大。若 $\mathbf{X} = \mathbf{0}$ ，则 $\mathbf{X}^\dagger = \mathbf{0}$ 。

这解释了贯穿例中的反差：两个大幅变化的系数沿近似相消方向移动，乘回 $\mathbf{X}_{\bar{\epsilon}}$ 后只留下很小的预测变化。若任务目标是区分两个特征各自的作用，这种敏感性是严重问题；若只关心训练设计空间内的预测，系数不稳定未必带来同等程度的预测不稳定。对新样本的外推仍可能敏感，因为新样本未必沿训练数据中相同的近共线关系变化。

岭正则化用

$$\hat{\boldsymbol{\beta}}_\lambda = (\mathbf{X}^\top \mathbf{X} + \lambda \mathbf{I})^{-1} \mathbf{X}^\top \mathbf{y}, \quad \lambda > 0,$$

把每个 $\sigma_i > 0$ 的右奇异方向上的逆缩放从 $1/\sigma_i$ 改为

$$\frac{\sigma_i}{\sigma_i^2 + \lambda}. \quad (6.41)$$

零奇异方向在伪逆与岭映射中都给出零系数；正奇异值很小的方向不再被大幅放大，但估计会向零收缩。正则化是在偏差与敏感性之间作选择，不是把原问题无代价地“修好”。 λ 的尺度也依赖特征缩放，不能脱离数据单

位比较。

6.5.4 特征值与子空间对扰动的反应不同

对称矩阵的特征值相对稳定。若 $\mathbf{A}$ 与 $\tilde{\mathbf{A}} = \mathbf{A} + \mathbf{E}$ 都对称, Weyl 不等式给出

$$|\tilde{\lambda}_i - \lambda_i| \leq \|\mathbf{E}\|_2, \quad (6.42)$$

其中两组特征值都按降序排列⁴。

这个界可以由定理 6.3 逐指标证明。令 $E_i = \text{span}\{\mathbf{q}_1, \dots, \mathbf{q}_i\}$, $F_i = \text{span}\{\mathbf{q}_i, \dots, \mathbf{q}_d\}$, 其中 $\mathbf{q}_j$ 是 $\mathbf{A}$ 的第 j 个标准正交特征向量。对任意单位向量 $\mathbf{x}$,

$$-\|\mathbf{E}\|_2 \leq \mathbf{x}^\top \mathbf{E} \mathbf{x} \leq \|\mathbf{E}\|_2.$$

在 Courant–Fischer 公式的第一个表达式中选 $S = E_i$, 得到

$$\tilde{\lambda}_i \geq \min_{\substack{\mathbf{x} \in E_i \\ \|\mathbf{x}\|_2=1}} \mathbf{x}^\top (\mathbf{A} + \mathbf{E}) \mathbf{x} \geq \lambda_i - \|\mathbf{E}\|_2.$$

在第二个表达式中选 $T = F_i$, 则

$$\tilde{\lambda}_i \leq \max_{\substack{\mathbf{x} \in F_i \\ \|\mathbf{x}\|_2=1}} \mathbf{x}^\top (\mathbf{A} + \mathbf{E}) \mathbf{x} \leq \lambda_i + \|\mathbf{E}\|_2.$$

上下界合并便得到式 (6.42), 而且论证对每个 i 分别成立。

比较特征方向和奇异方向之前, 先统一子空间夹角的记号。设 $\mathbf{Q}, \tilde{\mathbf{Q}} \in \mathbb{R}^{d \times r}$ 都具有标准正交列, 它们张成的两个 r 维子空间之间的**主角**(principal angles) $0 \leq \theta_1 \leq \dots \leq \theta_r \leq \pi/2$ 由 $\mathbf{Q}^\top \tilde{\mathbf{Q}}$ 的奇异值 $\cos \theta_1, \dots, \cos \theta_r$ 定义。记

$$\Theta(\mathbf{Q}, \tilde{\mathbf{Q}}) = \text{diag}(\theta_1, \dots, \theta_r), \quad \sin \Theta(\mathbf{Q}, \tilde{\mathbf{Q}}) = \text{diag}(\sin \theta_1, \dots, \sin \theta_r).$$

这些量只依赖于子空间, 不依赖其中选择的标准正交基。一维时, $\angle(\mathbf{q}, \tilde{\mathbf{q}}) = \arccos |\mathbf{q}^\top \tilde{\mathbf{q}}|$ 就是唯一的主角; 绝对值消除了特征向量正负号的任意性。若 $\mathbf{P} = \mathbf{Q}\mathbf{Q}^\top$ 且 $\tilde{\mathbf{P}} = \tilde{\mathbf{Q}}\tilde{\mathbf{Q}}^\top$, 则

$$\|\mathbf{P} - \tilde{\mathbf{P}}\|_2 = \|\sin \Theta(\mathbf{Q}, \tilde{\mathbf{Q}})\|_2 = \sin \theta_r.$$

一个二阶算例先展示谱隙为何出现在方向误差的分母中。令

$$\mathbf{A}_\gamma = \begin{bmatrix} 1+\gamma & 0 \\ 0 & 1 \end{bmatrix}, \quad \mathbf{E}_\epsilon = \begin{bmatrix} 0 & \epsilon \\ \epsilon & 0 \end{bmatrix}, \quad \gamma > 0, \quad \epsilon > 0.$$

原矩阵最大特征值与其余特征值的间隙是 γ , 扰动范数为 ϵ 。若扰动后最大特征向量与 $\mathbf{e}_1$ 的夹角为 $\theta \in (0, \pi/4)$, 直接解二阶对称矩阵的特征方程

⁴ R. A. Horn, C. R. Johnson, *Matrix Analysis*, Cambridge University Press, 2013, 2nd ed.

可得

$$\tan(2\theta) = \frac{2\epsilon}{\gamma}.$$

当 $\epsilon \ll \gamma$ 时, $\theta \approx \epsilon/\gamma$ 。因此, 在扰动大小相同的情况下, 谱隙越小, 特征方向越容易旋转; 当扰动与谱隙同量级时, 线性近似也不再足以描述转角。

特征向量却依赖谱间隙。设 λ_i 是单特征值, $\mathbf{q}_i$ 为对应单位特征向量, 扰动后的对应方向为 $\tilde{\mathbf{q}}_i$, 对应特征值为 $\tilde{\lambda}_i$ 。定义它与原矩阵其余特征值的实际分离量

$$\text{sep}_i = \min_{j \neq i} |\tilde{\lambda}_i - \lambda_j|.$$

若 $\text{sep}_i > 0$, 一维 Davis–Kahan 残差界给出

$$\sin \angle(\mathbf{q}_i, \tilde{\mathbf{q}}_i) \leq \frac{\|\mathbf{E}\|_2}{\text{sep}_i}. \quad (6.43)$$

这是把扰动特征方程投影到 $\mathbf{q}_i^\perp$ 后, 对 $\mathbf{A} - \tilde{\lambda}_i \mathbf{I}$ 在该子空间上求逆得到的⁵。若记原始间隙 $\delta_i = \min_{j \neq i} |\lambda_i - \lambda_j|$, Weyl 不等式还给出 $\text{sep}_i \geq \delta_i - \|\mathbf{E}\|_2$ 。这个形式明确显示: 真正控制方向变化的是扰动后目标值与原补谱之间仍然剩下的间隙。

⁵ R. A. Horn, C. R. Johnson, *Matrix Analysis*, Cambridge University Press, 2013, 2nd ed.

多个相邻特征值组成一簇时, 应直接比较子空间。若 $\mathbf{Q}_r$ 与 $\tilde{\mathbf{Q}}_r$ 的列分别张成两个 r 维子空间, 记它们的正交投影为 $\mathbf{P} = \mathbf{Q}_r \mathbf{Q}_r^\top$ 与 $\tilde{\mathbf{P}} = \tilde{\mathbf{Q}}_r \tilde{\mathbf{Q}}_r^\top$, 定义距离

$$d(\mathbf{Q}_r, \tilde{\mathbf{Q}}_r) = \|\mathbf{P} - \tilde{\mathbf{P}}\|_2 = \|\sin \Theta(\mathbf{Q}_r, \tilde{\mathbf{Q}}_r)\|_2.$$

这个量不随子空间内部选择哪一组标准正交基而改变。若 $\text{sep}_r = \tilde{\lambda}_r - \lambda_{r+1} > 0$, 则前 r 维特征子空间满足 Davis–Kahan 界

$$\|\mathbf{P} - \tilde{\mathbf{P}}\|_2 \leq \frac{\|\mathbf{E}\|_2}{\text{sep}_r}.$$

证明的关键不是逐个匹配簇内特征向量, 而是把扰动后的特征方程投影到原子空间的正交补; 该补空间上的谱与扰动后目标谱簇至少相隔 sep_r , 因而可以除以这个间隙来控制泄漏分量⁶。若原边界间隙 $\delta = \lambda_r - \lambda_{r+1} > 0$, 则 Weyl 不等式给出 $\text{sep}_r \geq \delta - \|\mathbf{E}\|_2$; 只有这个余量为正时, 上述前 r 维谱簇才保持分离。

⁶ R. A. Horn, C. R. Johnson, *Matrix Analysis*, Cambridge University Press, 2013, 2nd ed.

重特征值揭示了这个结论的边界。若 $\mathbf{A} = \lambda \mathbf{I}$, 任意单位向量都是特征向量; 一个任意小的对称扰动都可以选出完全不同的坐标方向。此时要求某个特征向量稳定没有意义, 稳定对象应改为整个重特征值对应的不变子空间。类似地, PCA 中若第 k 与第 $k+1$ 个奇异值非常接近, 前 k 维子空间的边界容易变化; 若关心的是包含整个重数块的更大子空间, 则可能仍然稳定。例如 $\mathbf{A} = \text{diag}(2, 2, 0)$ 的前二维特征空间可用 $\mathbf{e}_1, \mathbf{e}_2$ 表示, 也可用任意角度 θ 旋转后的 $\cos \theta \mathbf{e}_1 + \sin \theta \mathbf{e}_2$ 与 $-\sin \theta \mathbf{e}_1 + \cos \theta \mathbf{e}_2$ 表示。基向

量可旋转任意角度，对应投影却始终是 $\text{diag}(1, 1, 0)$ 。

6.5.5 奇异向量与奇异子空间也需要谱隙

一般矩阵的奇异值可通过对称扩张接入前述扰动结论。对 $\mathbf{A} \in \mathbb{R}^{m \times n}$ 定义

$$\mathcal{H}(\mathbf{A}) = \begin{bmatrix} \mathbf{0} & \mathbf{A} \\ \mathbf{A}^\top & \mathbf{0} \end{bmatrix}.$$

若 $(\mathbf{u}_i, \mathbf{v}_i, \sigma_i)$ 是一个奇异三元组，则 $2^{-1/2}(\mathbf{u}_i^\top, \mathbf{v}_i^\top)^\top$ 与 $2^{-1/2}(\mathbf{u}_i^\top, -\mathbf{v}_i^\top)^\top$ 分别是 $\mathcal{H}(\mathbf{A})$ 对应于 σ_i 与 $-\sigma_i$ 的特征向量。扰动 $\tilde{\mathbf{A}} = \mathbf{A} + \mathbf{E}$ 在扩张后仍是对称扰动，且 $\|\mathcal{H}(\mathbf{E})\|_2 = \|\mathbf{E}\|_2$ 。Weyl 不等式于是给出

$$|\tilde{\sigma}_i - \sigma_i| \leq \|\mathbf{E}\|_2. \quad (6.44)$$

奇异值本身不需要谱隙也能稳定变化，但要识别对应方向，还必须把目标奇异值与其余谱分开⁷。

具体地，设 $\mathbf{U}_k, \mathbf{V}_k$ 分别张成 $\mathbf{A}$ 的前 k 个左、右奇异子空间， $\tilde{\mathbf{U}}_k, \tilde{\mathbf{V}}_k$ 是扰动矩阵的对应子空间，并令边界谱隙

$$\text{sep}_W = \tilde{\sigma}_k - \sigma_{k+1} > 0,$$

其中越过矩阵秩的奇异值按零计。令

$$\mathbf{R} = \mathbf{A}\tilde{\mathbf{V}}_k - \tilde{\mathbf{U}}_k\tilde{\Sigma}_k, \quad \mathbf{S} = \mathbf{A}^\top\tilde{\mathbf{U}}_k - \tilde{\mathbf{V}}_k\tilde{\Sigma}_k.$$

由于 $\tilde{\mathbf{A}} = \mathbf{A} + \mathbf{E}$ ，这两个残差分别等于 $-\mathbf{E}\tilde{\mathbf{V}}_k$ 与 $-\mathbf{E}^\top\tilde{\mathbf{U}}_k$ 。Wedin 正弦定理的 Frobenius 范数版本给出

$$(\|\sin \Theta(\mathbf{U}_k, \tilde{\mathbf{U}}_k)\|_F^2 + \|\sin \Theta(\mathbf{V}_k, \tilde{\mathbf{V}}_k)\|_F^2)^{1/2} \leq \frac{(\|\mathbf{R}\|_F^2 + \|\mathbf{S}\|_F^2)^{1/2}}{\text{sep}_W}. \quad (6.45)$$

左端使用前面定义的主角，同时汇总左右奇异子空间的偏离。这个残差形式避免在未固定范数与分离量定义时写入额外常数，并直接显示子空间误差由“奇异方程没有满足到什么程度”与“目标簇还剩多大间隙”共同控制⁸。这个结论允许前 k 个奇异值内部重复：只要第 k 与第 $k+1$ 个奇异值之间存在间隙，整个前 k 维子空间仍可稳定；若还要辨认其中某个单独奇异向量，则该奇异值与两侧相邻奇异值都要分离。没有边界谱隙时，小扰动可以在几乎等价的方向之间大幅旋转，此时只能讨论包含完整奇异值簇的子空间，不能把某个数值算法返回的基向量当作可辨识对象。

⁷ R. A. Horn, C. R. Johnson, *Matrix Analysis*, Cambridge University Press, 2013, 2nd ed.

⁸ G. H. Golub, C. F. Van Loan, *Matrix Computations*, Johns Hopkins University Press, 2013, 4th ed.

6.6 稳定求解把结构转化为可靠计算

评价下面的求解方法时，“稳定”主要指**后向稳定** (backward stability)：算法返回的结果是某个邻近输入问题的精确解。它衡量算法引入的等效输入扰动，不能单独保证计算结果接近原问题的真解；后者还取决于问题的条件数。本节末尾将用残差、前向误差与后向误差把这一区别形式化。

6.6.1 消元与分解避免重复工作

求解 $\mathbf{Ax} = \mathbf{b}$ 时，显式计算 $\mathbf{A}^{-1}$ 再乘 $\mathbf{b}$ 通常不是合适的实现。高斯消元把 $\mathbf{A}$ 化为三角形式，随后用前代与回代求解。若有多个右端，同一个分解可以重复使用。对一般稠密方阵，带主元选取的 LU 分解写作

$$\mathbf{PA} = \mathbf{LU}, \quad (6.46)$$

其中 $\mathbf{P}$ 是置换矩阵， $\mathbf{L}$ 为单位下三角矩阵， $\mathbf{U}$ 为上三角矩阵。对非奇异矩阵，主元选取可避免因当前候选主元为零而中断，并抑制消元过程中元素的过度增长；秩亏矩阵仍会出现零主元，此时算法应报告秩亏或改用相应的分解。

主元选取不能改善问题的条件数，只抑制计算过程额外放大舍入误差。矩阵具有对称、正定、带状或稀疏结构时，还应选用保留相应结构的分解。

这种说法依赖浮点计算的基本模型。排除上溢、下溢等异常后，一次基本运算通常写成

$$\text{fl}(a \circ b) = (a \circ b)(1 + \delta), \quad |\delta| \leq u,$$

其中 $\circ$ 表示一次加、减、乘或除， u 是单位舍入误差。许多局部舍入误差会在消元中传播；带部分主元的 LU 通常具有良好表现，但严格后向误差界还含主元增长因子，不能无条件声称所有矩阵上的增长都很小。QR 的正交变换、正定矩阵上的 Cholesky 以及满足各自前提的稳定实现，也都应在这一误差模型下讨论，而不是把精确算术恒等式直接当成浮点保证。

6.6.2 QR 直接处理最小二乘

若 $\mathbf{A} \in \mathbb{R}^{m \times n}$ 且 $m \geq n$ 、列满秩，经济型 QR 分解写作 $\mathbf{A} = \mathbf{QR}$ ，其中 $\mathbf{Q} \in \mathbb{R}^{m \times n}$ 满足 $\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}$ ， $\mathbf{R} \in \mathbb{R}^{n \times n}$ 为可逆上三角矩阵。最小二乘目标变为

$$\|\mathbf{Ax} - \mathbf{b}\|_2^2 = \|\mathbf{Rx} - \mathbf{Q}^\top \mathbf{b}\|_2^2 + \|(\mathbf{I} - \mathbf{QQ}^\top)\mathbf{b}\|_2^2.$$

第二项与 $\mathbf{x}$ 无关，所以只需求解三角系统 $\mathbf{Rx} = \mathbf{Q}^\top \mathbf{b}$ 。

Householder 反射是计算稠密 QR 的常用稳定方法。经典 Gram-Schmidt 在列近相关时可能因消去误差丢失正交性；矩阵可能秩亏时，可用带列主

元的 QR 估计数值秩，或用 SVD 直接检查奇异值⁹。

对 $\mathbf{X}_{\tilde{\epsilon}}$ ，正规方程把条件数平方，而 QR 只通过正交变换和三角求解处理原矩阵的尺度。SVD 成本通常更高，却能显式识别 $\sigma_{\min}$ 并支持截断或正则化。选择方法时应同时考虑精度、秩判断需求与计算规模。

⁹ G. H. Golub, C. F. Van Loan, *Matrix Computations*, Johns Hopkins University Press, 2013, 4th ed.

6.6.3 Cholesky 利用正定性

若 $\mathbf{A}$ 实对称正定，则存在唯一的下三角矩阵 $\mathbf{L}$ ，其对角元为正，并满足

$$\mathbf{A} = \mathbf{L}\mathbf{L}^{\top}. \quad (6.47)$$

这称为 Cholesky 分解。求解时依次计算 $\mathbf{L}\mathbf{z} = \mathbf{b}$ 和 $\mathbf{L}^{\top}\mathbf{x} = \mathbf{z}$ 。与一般 LU 相比，它利用对称性减少约一半存储和运算，并且不需要主元选取。

半正定矩阵可能出现零主元，理论上半正定的矩阵也可能因舍入产生微小负特征值，导致 Cholesky 失败。盲目添加固定“小常数”会改变问题；应先判断原因，再选择正则化、带主元分解或特征值修正。

对岭回归， $\mathbf{X}^{\top}\mathbf{X} + \lambda\mathbf{I}$ 在 $\lambda > 0$ 时正定，可以用 Cholesky 求解。但形成 $\mathbf{X}^{\top}\mathbf{X}$ 仍可能损失信息。在高精度要求或极端病态情形下，把正则化问题写成增广最小二乘 $\min_{\beta} \|[\mathbf{X}^{\top}, \sqrt{\lambda}\mathbf{I}]^{\top}\beta - [\mathbf{y}^{\top}, \mathbf{0}^{\top}]^{\top}\|_2$ 并用 QR 求解，可以避免显式平方原设计矩阵的条件数。

6.6.4 稀疏大规模问题依赖矩阵向量乘法

当 $\mathbf{A}$ 规模很大且稀疏时，存储完整分解可能比原矩阵稠密得多。**迭代法** (iterative method) 从初值出发，通过矩阵向量乘法逐步逼近解。对对称正定系统，共轭梯度法在精确算术中至多 d 步得到精确解；实际浮点计算中更重要的结论是，其收敛速度受特征值分布和条件数影响。

共轭梯度的经典误差界含有因子 $((\sqrt{\kappa_2(\mathbf{A})} - 1)/(\sqrt{\kappa_2(\mathbf{A})} + 1))^t$ ：条件数大时最坏情况收敛较慢，但特征值聚簇常使实际收敛优于只看端点的界。

预条件 (preconditioning) 选择容易求解的 $\mathbf{M} \approx \mathbf{A}$ ，把系统变换为谱更集中的等价问题。目标不是让 $\mathbf{M}^{-1}\mathbf{A}$ 在符号上更复杂，而是减少迭代次数，同时保持每步成本可控。预条件器若构造或应用过于昂贵，即使降低了条件数也未必缩短总时间。非对称系统通常使用 GMRES 等 Krylov 子空间方法；不同方法的适用条件不能互换。

6.6.5 残差、前向误差与后向误差回答不同问题

先设 $\mathbf{A} \in \mathbb{R}^{d \times d}$ 可逆， $\mathbf{x} = \mathbf{A}^{-1}\mathbf{b}$ 是原方程的唯一真解。给定计算结果 $\hat{\mathbf{x}}$ ，其 **残差** (residual) 为

$$\mathbf{r} = \mathbf{b} - \mathbf{A}\hat{\mathbf{x}}. \quad (6.48)$$

残差小表示 $\hat{\mathbf{x}}$ 几乎满足原方程，但不直接保证它接近真解 $\mathbf{x}$ 。因为 $\mathbf{x} - \hat{\mathbf{x}} = \mathbf{A}^{-1}\mathbf{r}$ ，病态矩阵可以把很小的残差转成很大的前向误差。

一个二阶例子足以看到差别。取 $\mathbf{A} = \text{diag}(1, \epsilon)$ 、 $\mathbf{b} = (1, \epsilon)^\top$ ，其中 $0 < \epsilon \ll 1$ 。真解为 $\mathbf{x} = (1, 1)^\top$ 。若计算结果是 $\hat{\mathbf{x}} = (1, 0)^\top$ ，则

$$\mathbf{r} = (0, \epsilon)^\top, \quad \frac{\|\mathbf{r}\|_2}{\|\mathbf{b}\|_2} = \frac{\epsilon}{\sqrt{1 + \epsilon^2}}, \quad \frac{\|\hat{\mathbf{x}} - \mathbf{x}\|_2}{\|\mathbf{x}\|_2} = \frac{1}{\sqrt{2}}.$$

相对残差随 ϵ 趋于零，前向误差却保持常数量级，因为 $\kappa_2(\mathbf{A}) = 1/\epsilon$ 。小残差是方程几乎满足的证据，不是参数已经求准的充分条件。

前向误差 (forward error) 直接比较 $\hat{\mathbf{x}}$ 与真解；**后向误差** (backward error) 则问： $\hat{\mathbf{x}}$ 究竟是哪一个邻近问题的精确解？若只允许扰动右端，有 $\mathbf{A}\hat{\mathbf{x}} = \mathbf{b} - \mathbf{r}$ ，所以当 $\mathbf{b} \neq \mathbf{0}$ 时， $\|\mathbf{r}\|_2/\|\mathbf{b}\|_2$ 就是只扰动右端的相对后向误差。当 $\mathbf{b} = \mathbf{0}$ 时，这个比值没有定义，不能把分母改成任意小常数；此时可以报告绝对残差，或允许矩阵与右端共同扰动。

对一般矩阵 $\mathbf{A} \in \mathbb{R}^{m \times n}$ ，共同扰动的范数型相对后向误差定义为

$$\eta_2(\hat{\mathbf{x}}; \mathbf{A}, \mathbf{b}) = \min_{\epsilon, \Delta\mathbf{A}, \Delta\mathbf{b}} \left\{ \epsilon \geq 0 : \begin{array}{l} (\mathbf{A} + \Delta\mathbf{A})\hat{\mathbf{x}} = \mathbf{b} + \Delta\mathbf{b}, \\ \|\Delta\mathbf{A}\|_2 \leq \epsilon\|\mathbf{A}\|_2, \quad \|\Delta\mathbf{b}\|_2 \leq \epsilon\|\mathbf{b}\|_2 \end{array} \right\}.$$

令 $d = \|\mathbf{A}\|_2\|\hat{\mathbf{x}}\|_2 + \|\mathbf{b}\|_2$ 。当 $d > 0$ 时，这个最小值具有闭式

$$\eta_2(\hat{\mathbf{x}}; \mathbf{A}, \mathbf{b}) = \frac{\|\mathbf{r}\|_2}{\|\mathbf{A}\|_2\|\hat{\mathbf{x}}\|_2 + \|\mathbf{b}\|_2}.$$

确实，扰动方程等价于 $\Delta\mathbf{A}\hat{\mathbf{x}} - \Delta\mathbf{b} = \mathbf{r}$ ，三角不等式先给出右侧比值作为下界；再让 $\Delta\mathbf{A}\hat{\mathbf{x}}$ 与 $-\Delta\mathbf{b}$ 都沿 $\mathbf{r}$ 方向，并按两项分母的大小分配残差，就能达到该下界。这个定义也覆盖 $\mathbf{b} = \mathbf{0}$ 且 $d > 0$ 的情形，此时全部等效扰动由矩阵承担。若 $d = 0$ ，则必有 $\mathbf{b} = \mathbf{0}$ 且 $\mathbf{A}\hat{\mathbf{x}} = \mathbf{0}$ ，计算结果已经精确满足原方程，约定 $\eta_2 = 0$ 。

一个算法称为后向稳定，意指它返回的是某个与输入很接近的问题的精确解。后向稳定加上问题条件良好，才能推出前向误差小。若 $\kappa(\mathbf{A})$ 很大，即使算法完全后向稳定，前向解仍可能不可靠。这一区分把责任分清：条件数描述问题对输入误差的敏感性，后向稳定性描述算法额外引入了多大等效扰动。

若输出本身需要逆矩阵的许多元素，可以通过稳定分解求逆并检查条件数。但若目标只是计算 $\mathbf{A}^{-1}\mathbf{b}$ 、二次型 $\mathbf{b}^\top \mathbf{A}^{-1}\mathbf{b}$ 或 $\mathbf{A}^{-1}\mathbf{U}$ ，线性求解通常更省计算、更少存储，也更容易复用结构。对式 (6.1) 这样的病态矩阵，换一种写法不能恢复数据中没有的信息；合理做法是报告敏感性、引入有依据的正则化，或把目标改为可稳定识别的预测和子空间。

6.7 本章小结

矩阵分析把“可逆或不可逆”的二分判断细化为方向性的描述。对称谱分解与 Rayleigh 商找出二次型最强和最弱的方向；SVD 把这一观点推广到任意矩阵，并同时刻画值域、零空间、低秩近似和最小二乘。矩阵范数把不同方向的作用汇总成适合具体误差问题的尺度，有效秩则避免把微小奇异值与主要结构等量齐观；这里的稳定秩不同于核方法中随正则化尺度变化的有效维度。

近共线例说明了这些工具为何需要连在一起使用。小奇异值意味着某个系数方向几乎被设计矩阵压扁；伪逆会在反向求解时放大该方向，截断 SVD 与岭正则化则以不同方式抑制它。由此产生的系数敏感不必等同于训练拟合值敏感，但会削弱参数解释，并可能危及训练数据范围外的预测。谱间隙进一步决定特征向量、奇异向量或相应子空间在扰动下是否可辨识。

可靠计算还需要把问题条件与算法稳定性分开。LU、QR、Cholesky、SVD 和迭代法利用的结构不同；残差小只说明方程满足得好，只有结合条件数与后向误差，才能判断前向解是否可信。矩阵函数、Schur 补、Woodbury 恒等式、Kronecker 积和极分解则展示了另一条原则：先识别结构，再选择运算形式。矩阵函数的 Fréchet 导数还说明，非交换扰动不能照抄标量导数。后续使用这些工具时，既要写出成立条件，也要说明保留、舍弃或正则化了哪些方向。第 7 章将进一步离开固定线性空间，研究弯曲点带上的局部坐标、切空间、度量与对称性。

第 7 章

微分几何与对称性

前两章都在一个固定向量空间中讨论坐标。换基会改变数字表示，却不会改变向量、线性关系和内积；谱与奇异值又说明，线性映射沿不同方向保留了多少信息。但许多数据并不接近一个贯穿全局的低维线性子空间。一条一维曲线可以在环境空间中弯曲，观测点也可能在曲线周围散开成有厚度的带。前者只有一个内在自由度，后者若被当作连续几何对象则有两个内在自由度；测量噪声又是对潜在点的扰动，不会自动成为新的流形坐标。若不先分清这些对象，“沿带移动”究竟允许哪些路径便没有确定含义。

本章以一条**弯曲点带**贯穿讨论。先考虑平面中的连续带

$$\Phi(s, u) = \begin{bmatrix} (R + u) \cos(s/R) \\ (R + u) \sin(s/R) \end{bmatrix}, \quad s \in I, \quad |u| < w < R, \quad (7.1)$$

其中 $I = (s_-, s_+) \subset \mathbb{R}$ 是长度小于 $2\pi R$ 的开区间， s 表示沿中心线的位置， u 表示横向偏移。这个长度限制使参数化不会绕圆一周后重复。二维带和它的一维中心线分别记为

$$\mathcal{M}_{\text{strip}} = \{\Phi(s, u) : s \in I, |u| < w\}, \quad \mathcal{C} = \{\Phi(s, 0) : s \in I\}.$$

采样时， $\mathbf{p}_i = \Phi(s_i, u_i) \in \mathcal{M}_{\text{strip}}$ 表示无噪声的**潜在点** (latent point)， $\mathbf{x}_i = \mathbf{p}_i + \boldsymbol{\epsilon}_i \in \mathbb{R}^2$ 才是带测量误差的观测；由于二维开带是 $\mathbb{R}^2$ 的开子集，任一内部潜在点周围都有完全落在带内的小球，足够小的扰动仍会使 $\mathbf{x}_i \in \mathcal{M}_{\text{strip}}$ 。没有噪声界时则不能保证这一点，而且即使观测仍在带内， $\mathbf{x}_i$ 也不等于生成它的潜在点。若建模对象是一维中心线，则还须令潜在点满足 $u_i = 0$ ，并把横向偏离归入观测误差；一般环境扰动会使 $\mathbf{x}_i \notin \mathcal{C}$ ，不能同时把 u 当作第二个内在坐标。后文将始终区分二维带 $\mathcal{M}_{\text{strip}}$ 、一维中心线 $\mathcal{C}$ 、潜在点 $\mathbf{p}_i$ 和带噪观测 $\mathbf{x}_i$ 。

我们先问点间距离能恢复哪些坐标信息，再把局部坐标和切空间连接起来。局部内积随后决定路径长度与测地距离，函数沿空间变化的能量则引出几何拉普拉斯算子。坐标描述本来就不唯一，因此还要进一步说明一组变换如何构成群作用，以及不变性与等变性分别要求输出怎样响应。局

部坐标仍看不到连通分支和环，本章最后用单纯复形说明怎样把局部邻接组合成整体拓扑信息。所有结论都附带尺度、光滑性或采样条件；低维几何本身不保证它与某个预测任务的语义一致。

7.1 距离与坐标嵌入

7.1.1 距离保留关系，却不固定坐标原点和朝向

先考虑 n 个无噪声点 $\mathbf{y}_1, \dots, \mathbf{y}_n \in \mathbb{R}^d$ ，将它们按行组成矩阵 $\mathbf{Y} \in \mathbb{R}^{n \times d}$ 。这些点可以取为前述潜在点；若把带噪观测直接代入，以下结论只会重构观测距离，而不会自动恢复潜在距离。点的Gram矩阵记录两两内积：

$$\mathbf{B} = \mathbf{Y}\mathbf{Y}^\top, \quad b_{i,j} = \mathbf{y}_i^\top \mathbf{y}_j.$$

若已知 $\mathbf{B}$ ，平方距离可以由

$$\delta_{i,j} = \|\mathbf{y}_i - \mathbf{y}_j\|_2^2 = b_{i,i} + b_{j,j} - 2b_{i,j} \quad (7.2)$$

得到。反向恢复却多一个困难：距离不记录原点。把每个点同时平移 $\mathbf{a} \in \mathbb{R}^d$ ，全部差向量和距离都不变，内积却通常改变。

可以先选择一个规范来消除平移自由度。本节把点云中心放在原点，即要求 $\sum_i \mathbf{y}_i = \mathbf{0}$ 。令 $\mathbf{1} \in \mathbb{R}^n$ 为全一向量，并定义中心化矩阵

$$\mathbf{J} = \mathbf{I}_n - \frac{1}{n} \mathbf{1}\mathbf{1}^\top. \quad (7.3)$$

它满足 $\mathbf{J}^\top = \mathbf{J}$ 、 $\mathbf{J}^2 = \mathbf{J}$ 和 $\mathbf{J}\mathbf{1} = \mathbf{0}$ ，所以是到与 $\mathbf{1}$ 正交的子空间上的投影。对任意点矩阵， $\mathbf{J}\mathbf{Y}$ 恰好从每一行减去样本均值。

把平方距离组成矩阵 $\Delta \in \mathbb{R}^{n \times n}$ ，其中 $\Delta_{i,j} = \delta_{i,j}$ 。式 (7.2) 可写成

$$\Delta = \text{diag}(\mathbf{B})\mathbf{1}\mathbf{1}^\top + \mathbf{1}\text{diag}(\mathbf{B})^\top - 2\mathbf{B}.$$

在左右两侧同时乘 $\mathbf{J}$ 时，前两项因 $\mathbf{J}\mathbf{1} = \mathbf{0}$ 而消失。若点云已经中心化，则 $\mathbf{J}\mathbf{Y} = \mathbf{Y}$ ，从而 $\mathbf{J}\mathbf{B}\mathbf{J} = \mathbf{B}$ 。于是得到

$$\mathbf{B} = -\frac{1}{2} \mathbf{J}\Delta\mathbf{J}. \quad (7.4)$$

这一步称为距离矩阵的**双重中心化** (double centering)。它不是把已有坐标投影到某个子空间，而是从点间关系重新构造一组以均值为原点的内积。

7.1.2 正半定性判断距离能否来自欧氏坐标

任意实矩阵 $\mathbf{Y}$ 产生的 $\mathbf{B} = \mathbf{Y}\mathbf{Y}^\top$ 都半正定，因为

$$\mathbf{c}^\top \mathbf{B} \mathbf{c} = \|\mathbf{Y}^\top \mathbf{c}\|_2^2 \geq 0.$$

这个必要条件也是有限点欧氏嵌入的核心判据。

引理 7.1 双重中心化核的形式 设 $\mathbf{H} \in \mathbb{R}^{n \times n}$ 对称。若 $\mathbf{J}\mathbf{H}\mathbf{J} = \mathbf{0}$ ，则存在 $\mathbf{a} \in \mathbb{R}^n$ 使

$$\mathbf{H} = \mathbf{1}\mathbf{a}^\top + \mathbf{a}\mathbf{1}^\top.$$

若进一步有 $h_{i,i} = 0$ 对所有 i 成立，则 $\mathbf{H} = \mathbf{0}$ 。

证明. 令 $\mathbf{m} = \mathbf{H}\mathbf{1}/n$ 且 $\mu = \mathbf{1}^\top \mathbf{H}\mathbf{1}/n^2$ 。展开 $\mathbf{J}\mathbf{H}\mathbf{J} = \mathbf{0}$ 得到

$$\mathbf{H} = \mathbf{1}\mathbf{m}^\top + \mathbf{m}\mathbf{1}^\top - \mu\mathbf{1}\mathbf{1}^\top.$$

取 $\mathbf{a} = \mathbf{m} - (\mu/2)\mathbf{1}$ 便得到所需形式。此时 $h_{i,i} = 2a_i$ ；若对角元全为零，则 $\mathbf{a} = \mathbf{0}$ ，从而 $\mathbf{H} = \mathbf{0}$ 。 ■

定理 7.2 有限距离的欧氏坐标重构 设 $\Delta \in \mathbb{R}^{n \times n}$ 对称、对角元为零，并令

$$\mathbf{B} = -\frac{1}{2}\mathbf{J}\Delta\mathbf{J}.$$

矩阵 Δ 是某组欧氏点的平方距离矩阵，当且仅当 $\mathbf{B}$ 半正定。若 $r = \text{rank}(\mathbf{B})$ ，则这些点可以嵌入 $\mathbb{R}^r$ ，但不能嵌入更低维的欧氏空间而精确保留全部距离。

证明. 若 Δ 来自欧氏点，先把点中心化。前面的双重中心化推导给出 $\mathbf{B} = \mathbf{Y}\mathbf{Y}^\top$ ，所以 $\mathbf{B}$ 半正定。

反过来，若 $\mathbf{B}$ 半正定，由谱定理可写

$$\mathbf{B} = \mathbf{Q}_r \mathbf{\Lambda}_r \mathbf{Q}_r^\top,$$

其中 $\mathbf{\Lambda}_r$ 只保留 r 个正特征值。取

$$\mathbf{Y} = \mathbf{Q}_r \mathbf{\Lambda}_r^{1/2}, \quad (7.5)$$

便有 $\mathbf{Y}\mathbf{Y}^\top = \mathbf{B}$ 。由 $\mathbf{B}\mathbf{1} = \mathbf{0}$ 可知 $\mathbf{Y}^\top \mathbf{1} = \mathbf{0}$ ，故坐标已经中心化。用式 (7.2) 从 $\mathbf{B}$ 构造平方距离，所得矩阵与 Δ 有相同的双重中心化结果。两者之差是对称矩阵、对角元为零，且双重中心化为零；引理 7.1 说明两者之差只能为零，所以距离完全相同。

最后, 任何坐标矩阵 $\tilde{\mathbf{Y}} \in \mathbb{R}^{n \times k}$ 产生的 Gram 矩阵秩至多为 k 。要得到秩为 r 的 $\mathbf{B}$, 必有 $k \geq r$; 式 (7.5) 又表明 $k = r$ 可以达到。 ■

这个重构过程是经典尺度分析的代数核心。若 $\mathbf{B}$ 有负特征值, 给定关系便不能作为欧氏平方距离被精确保留。实际计算有时只保留正特征值, 得到近似坐标; 此时舍弃负谱是一项近似选择, 不能把输出再称为原距离的精确实现。若各对距离分别带有测量误差, 彼此可能不再满足欧氏距离关系, 双重中心化后便可能出现很小的负特征值; 此时应结合误差尺度判断, 而不是见到负值就自动删除。若先获得一组带噪坐标再由它们精确计算成对距离, 所得双重中心化矩阵仍是这组观测坐标的 Gram 矩阵, 因而不会仅因坐标噪声而失去半正定性。

7.1.3 距离不能消除刚体变换造成的非唯一性

即使 $\mathbf{B}$ 半正定, 重构坐标也不唯一。给定正交矩阵 $\mathbf{Q} \in \mathbb{R}^{r \times r}$ 与平移 $\mathbf{a} \in \mathbb{R}^r$, 令

$$\tilde{\mathbf{y}}_i = \mathbf{Q} \mathbf{y}_i + \mathbf{a}.$$

由于 $\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}$,

$$\|\tilde{\mathbf{y}}_i - \tilde{\mathbf{y}}_j\|_2 = \|\mathbf{Q}(\mathbf{y}_i - \mathbf{y}_j)\|_2 = \|\mathbf{y}_i - \mathbf{y}_j\|_2.$$

正交矩阵既包括行列式为 1 的旋转, 也包括行列式为 -1 的反射。距离因此不能确定绝对位置、朝向或手性。中心化只固定平移, 仍保留正交自由度; 若特征值重复, 谱分解中的单个坐标轴还可以在相应子空间内任意旋转。

这也是中心化最小维坐标的全部不确定性。设 $\mathbf{Y}, \tilde{\mathbf{Y}} \in \mathbb{R}^{n \times r}$ 都列满秩、行均值为零, 并产生同一组距离。双重中心化给出 $\mathbf{Y} \mathbf{Y}^\top = \tilde{\mathbf{Y}} \tilde{\mathbf{Y}}^\top = \mathbf{B}$ 。取 $\mathbf{B}$ 的紧谱分解 $\mathbf{B} = \mathbf{Q}_r \mathbf{\Lambda}_r \mathbf{Q}_r^\top$ 。由于两组坐标的列空间都等于 $\mathbf{B}$ 的值域, 定义

$$\mathbf{M} = \mathbf{\Lambda}_r^{-1/2} \mathbf{Q}_r^\top \mathbf{Y}.$$

于是

$$\mathbf{Y} = \mathbf{Q}_r \mathbf{\Lambda}_r^{1/2} \mathbf{M}, \quad \mathbf{M} \mathbf{M}^\top = \mathbf{\Lambda}_r^{-1/2} \mathbf{Q}_r^\top \mathbf{Y} \mathbf{Y}^\top \mathbf{Q}_r \mathbf{\Lambda}_r^{-1/2} = \mathbf{I}_r.$$

矩阵 $\mathbf{M}$ 为方阵, 所以它是正交矩阵。令 $\mathbf{M} = \mathbf{U}^\top$, 并对 $\tilde{\mathbf{Y}}$ 作同样推导, 可写成

$$\mathbf{Y} = \mathbf{Q}_r \mathbf{\Lambda}_r^{1/2} \mathbf{U}^\top, \quad \tilde{\mathbf{Y}} = \mathbf{Q}_r \mathbf{\Lambda}_r^{1/2} \tilde{\mathbf{U}}^\top,$$

其中 $\mathbf{U}$ 和 $\tilde{\mathbf{U}}$ 均为 r 阶正交矩阵。因此 $\tilde{\mathbf{Y}} = \mathbf{Y} \mathbf{U} \tilde{\mathbf{U}}^\top$, 两者只差一个作用在坐标列上的正交变换。若允许更高维坐标, 同一结论应理解为两组点在各自张成空间之间存在保距正交对应, 而多出的环境方向不含点云信息。

一个三点算例可以同时核对距离、Gram 矩阵和非唯一性。取

$$\mathbf{y}_1 = (-1, 0)^\top, \quad \mathbf{y}_2 = (0, 1)^\top, \quad \mathbf{y}_3 = (1, 0)^\top.$$

其平方距离矩阵为

$$\Delta = \begin{bmatrix} 0 & 2 & 4 \\ 2 & 0 & 2 \\ 4 & 2 & 0 \end{bmatrix}.$$

原坐标均值为 $(0, 1/3)^\top$ 。双重中心化恢复的是减去该均值后的 Gram 矩阵

$$-\frac{1}{2}\mathbf{J}\Delta\mathbf{J} = \begin{bmatrix} 10/9 & -2/9 & -8/9 \\ -2/9 & 4/9 & -2/9 \\ -8/9 & -2/9 & 10/9 \end{bmatrix}, \quad (7.6)$$

其两个正特征值为 2 和 $2/3$ ，所以精确欧氏嵌入至少需要二维。对重构坐标整体旋转或反射仍得到同一 Δ ；把原坐标直接拿来比较时，还要补回任意平移。

弯曲点带展示了“重构”和“投影”的区别。若已经给出无噪声潜在坐标 $\mathbf{p}_i = \Phi(s_i, u_i)$ ，PCA 是在这些坐标中寻找低维线性子空间，目标是控制坐标重构误差。若只给出潜在点之间的全部欧氏距离，式 (7.4) 先恢复一个与潜在点云刚体等价的坐标系统。若输入改为带噪观测 $\mathbf{x}_i$ 或其距离，两种方法处理的都是观测几何，不能据此声称已经恢复 $\mathbf{p}_i$ 。这些方法都使用谱分解，却从不同输入回答不同问题。

若只保留 $\mathbf{B}$ 最大的 $k < r$ 个正特征值，第 6.4 定理表明所得矩阵在 Frobenius 范数下是 $\mathbf{B}$ 的最佳秩 k 近似；当 $\mathbf{B}$ 来自中心化坐标时，相应投影也最小化坐标的平方重构误差。这个目标控制的是 Gram 矩阵或坐标重构，不是任意定义的成对距离误差。例如上述三点只保留特征值 2 对应的水平方向时，两端距离仍为 2，但顶点到两端的距离都从 $\sqrt{2}$ 变成 1。若应用真正关心距离应力、最大相对误差或局部邻接，就需要直接写出相应目标，不能只凭谱截断的最优性替代。

更重要的是，精确保留环境空间距离未必能把潜在点展开成沿 s 排列的直线。取一维中心线 $\mathcal{C}$ 上的两点 $\mathbf{p} = \Phi(s, 0)$ 与 $\mathbf{q} = \Phi(t, 0)$ ，它们在环境空间中的欧氏距离为

$$\|\Phi(s, 0) - \Phi(t, 0)\|_2 = 2R \left| \sin \frac{s-t}{2R} \right|, \quad (7.7)$$

它是圆弧的弦长，不是沿一维中心线 $\mathcal{C}$ 行走的弧长 $|s-t|$ 。所以距离重构只能忠实恢复所给的距离；若希望保留沿中心线或二维带行走的关系，还要先分别说明允许路径属于哪个对象，并定义局部运动的长度。

7.2 流形与局部线性化

7.2.1 局部坐标描述附近自由度

一条圆不能由单个实数坐标连续、无重复地覆盖全局，但圆上任意一点附近都可以用一个实数描述。微分几何把这种“局部像欧氏空间”的性质提炼为**流形**（manifold）¹。本章只处理嵌在欧氏空间中的光滑流形：集合 $\mathcal{M} \subseteq \mathbb{R}^D$ 称为 d 维光滑嵌入流形，如果每个 $\mathbf{p} \in \mathcal{M}$ 都存在包含 $\mathbf{p}$ 的环境开集 $O \subseteq \mathbb{R}^D$ 和欧氏开集之间的光滑微分同胚

$$\Psi : O \rightarrow \Psi(O) \subseteq \mathbb{R}^D,$$

使

$$\Psi(\mathcal{M} \cap O) = \Psi(O) \cap (\mathbb{R}^d \times \{\mathbf{0}_{D-d}\}).$$

这个条件只使用欧氏开集之间已经定义好的光滑映射，避免用尚未建立的“流形上的光滑逆”来定义流形自身。白话地说， Ψ 在 $\mathbf{p}$ 附近把 $\mathcal{M}$ 拉直成前 d 个坐标方向。

令 $U = \{\mathbf{z} \in \mathbb{R}^d : (\mathbf{z}, \mathbf{0}_{D-d}) \in \Psi(O)\}$ ，则

$$\varphi(\mathbf{z}) = \Psi^{-1}(\mathbf{z}, \mathbf{0}_{D-d})$$

是从 U 到 $\mathcal{M} \cap O$ 的光滑参数化，其 Jacobian 矩阵处处列满秩。参数化的逆映射称为**坐标图**（chart）。一个坐标图通常只能覆盖流形的一部分；若两个坐标图重叠，它们的**坐标过渡**（coordinate transition）由两组欧氏微分同胚复合得到，因而光滑且具有光滑逆。

单位圆 $\mathbb{S}^1$ 可在不跨越角度断点的小弧上写成 $\varphi(\theta) = (\cos \theta, \sin \theta)^\top$ 。在 $(-\pi, \pi)$ 中，接近 $(-1, 0)^\top$ 的同一段圆弧会遇到坐标端点；换用 $(0, 2\pi)$ 便把断点移到别处。几何对象没有断裂，断裂来自单张角度坐标图。局部坐标的存在不等于存在一个无奇点、无重复的全局坐标。

式 (7.1) 给点带内部提供了二维局部坐标 (s, u) 。其两个坐标方向为

$$\frac{\partial \Phi}{\partial s}(s, u) = \left(1 + \frac{u}{R}\right) \begin{bmatrix} -\sin(s/R) \\ \cos(s/R) \end{bmatrix}, \quad (7.8)$$

$$\frac{\partial \Phi}{\partial u}(s, u) = \begin{bmatrix} \cos(s/R) \\ \sin(s/R) \end{bmatrix}. \quad (7.9)$$

因为 $|u| < w < R$ ，第一列不为零，且两列正交，所以 Jacobian 矩阵秩为 2。若只考虑中心线 $u = 0$ ，对象则是一维曲线，只有 s 这个内在自由度。带的二维性、中心线的一维性和它们都位于二维环境空间，是三个不同陈述。

¹ J. M. Lee, *Introduction to Smooth Manifolds*, Springer, 2013, 2nd ed.

7.2.2 切空间收集可实现的一阶速度

在 $\mathbf{p} = \varphi(\mathbf{z})$ 处，**切空间** (tangent space) $T_{\mathbf{p}}\mathcal{M}$ 定义为参数化 Jacobian 矩阵的值域：

$$T_{\mathbf{p}}\mathcal{M} = \{\mathbf{J}_{\varphi}(\mathbf{z})\mathbf{v} : \mathbf{v} \in \mathbb{R}^d\}. \quad (7.10)$$

它不是经过原点附近的一块流形，而是一个以零速度为原点的向量空间，表示从 $\mathbf{p}$ 出发能够沿流形实现的全部一阶速度。

这个定义也可以从曲线得到。若 $\gamma : (-\epsilon, \epsilon) \rightarrow \mathcal{M}$ 光滑且 $\gamma(0) = \mathbf{p}$ ，在坐标中写 $\gamma(t) = \varphi(\mathbf{z}(t))$ ，链式法则给出

$$\gamma'(0) = \mathbf{J}_{\varphi}(\mathbf{z})\mathbf{z}'(0) \in T_{\mathbf{p}}\mathcal{M}.$$

反过来，任取 $\mathbf{v} \in \mathbb{R}^d$ ，曲线 $t \mapsto \varphi(\mathbf{z} + t\mathbf{v})$ 在足够小的 t 上位于流形内，其初速度就是 $\mathbf{J}_{\varphi}(\mathbf{z})\mathbf{v}$ 。因此切空间恰好收集所有流形内曲线的初速度。

若换用另一组坐标 $\tilde{\mathbf{z}}$ ，坐标过渡的 Jacobian 矩阵可逆。两组参数化 Jacobian 矩阵只相差右侧一个可逆矩阵，它们的值域相同，所以切空间不依赖坐标选择。坐标分量会变，切向量作为几何速度不会变。这延续了第 5 章对“对象”和“坐标”的区分，但现在每个点都有自己的切空间，不能未经搬运就把不同点处的切向量相加。

对中心圆弧 $\gamma(s) = \Phi(s, 0)$,

$$T_{\gamma(s)}\mathcal{C} = \text{span} \left\{ \begin{bmatrix} -\sin(s/R) \\ \cos(s/R) \end{bmatrix} \right\}.$$

切线方向随 s 旋转，所以没有一条固定直线能同时等于所有局部切空间。这正是全局线性子空间难以无失真表示弯曲曲线的原因。

7.2.3 局部 PCA 估计的是切方向，不是全局展开

只有带噪观测 $\mathbf{x}_i$ 时，参数化 Φ 和潜在点 $\mathbf{p}_i$ 通常都未知。此时必须先说明要估计的潜在流形是二维带 $\mathcal{M}_{\text{strip}}$ 还是一维中心线 $\mathcal{C}$ ，其维数分别为 2 和 1。局部 PCA 在 $\mathbf{x}_i$ 附近选择观测邻居、减去局部均值，再对局部数据矩阵做谱分解；它试图估计的是 $T_{\mathbf{p}_i}\mathcal{M}_{\text{strip}}$ 或 $T_{\mathbf{p}_i}\mathcal{C}$ 。对一维中心线或一般满足 $d < D$ 的嵌入流形，环境噪声通常会把观测推出潜在流形，此时 $T_{\mathbf{x}_i}\mathcal{M}$ 没有定义。当前二维开带则是 $\mathbb{R}^2$ 的开子集：足够小的扰动后 $\mathbf{x}_i$ 仍在带内，并且 $T_{\mathbf{x}_i}\mathcal{M}_{\text{strip}} = \mathbb{R}^2$ ；较大扰动也可能把它推出带外。两种情形下，局部 PCA 要估计的潜在对象仍是 $\mathbf{p}_i$ 处的切空间，而不是把观测点直接认作生成它的潜在点。

具体地，记邻居索引集为 N_i ，选取非负权重 $\alpha_{i,j}$ 并令 $\sum_{j \in N_i} \alpha_{i,j} = 1$ 。局

部均值和加权协方差矩阵定义为

$$\bar{\mathbf{x}}_i = \sum_{j \in N_i} \alpha_{i,j} \mathbf{x}_j, \quad \mathbf{C}_i = \sum_{j \in N_i} \alpha_{i,j} (\mathbf{x}_j - \bar{\mathbf{x}}_i)(\mathbf{x}_j - \bar{\mathbf{x}}_i)^\top. \quad (7.11)$$

取 $\mathbf{C}_i$ 最大 d 个特征值对应的特征向量张成估计切空间。这里 d 必须已知或另由局部谱判断；权重、邻域和维数都是构造的一部分。使用局部均值可以消去邻域的一阶位置偏移。特征向量给出的是以零速度为原点的方向子空间；若要画出局部仿射近似，可将它平移到 $\bar{\mathbf{x}}_i$ 。真实的仿射切平面应以潜在点 $\mathbf{p}_i$ 为锚点，但 $\mathbf{p}_i$ 未知；因此以 $\mathbf{x}_i$ 或局部均值为锚点得到的只是估计，不能称为 $\mathbf{x}_i$ 处的真实切平面。

这个结论来自局部 Taylor 展开。设无噪声邻居可写成 $\mathbf{p}_i = \varphi(\mathbf{z})$ 和 $\mathbf{p}_j = \varphi(\mathbf{z} + \mathbf{h})$ ，则

$$\varphi(\mathbf{z} + \mathbf{h}) - \varphi(\mathbf{z}) = \mathbf{J}_\varphi(\mathbf{z})\mathbf{h} + O(\|\mathbf{h}\|_2^2). \quad (7.12)$$

一阶项位于切空间，偏离切平面的法向分量由曲率通过二阶项出现。若邻域半径记为 h ，切向位移通常为 $O(h)$ ，曲率造成的法向位移为 $O(h^2)$ 。因此缩小邻域可以降低曲率偏差，却也减少可用样本，并使测量噪声相对于真实局部变化更突出。

两种潜在对象的误差机制不同。对一维中心线 $\mathcal{C}$ ，邻域过大时切线已经随 s 明显旋转，PCA 得到的是多段切线的折中；邻域过小时，样本又可能只沿偶然方向排列。对二维带 $\mathcal{M}_{\text{strip}}$ ，切空间在当前平面例子中就是 $\mathbb{R}^2$ ，不能因点带狭窄就把它改称一维流形；但当横向宽度 w 小于噪声尺度时，有限样本中的第二个内在方向仍可能无法稳定辨认。局部谱间隙、采样密度、曲率、带宽、潜在对象和测量误差必须共同解释，不能仅按某个固定邻居数宣布“数据维数”。

内在维数也不等于能够无失真嵌入的最小全局维数。圆是一维流形，却不能以保持其拓扑的方式用一张实数坐标图覆盖；它可以无自交地嵌入二维平面。局部 PCA 回答附近有多少一阶自由度，并不自动构造全局参数 s ，更不能保证参数化在整条点带上不重叠。

7.3 度量、路径与测地距离

7.3.1 度量在每个切空间规定长度和角度

切空间只说明哪些一阶速度可行，还没有规定不同速度有多长。流形上的 **Riemann 度量** (Riemannian metric) 为每个点 $\mathbf{p}$ 的切空间指定一个随 $\mathbf{p}$ 光滑变化的内积 $\mathbf{g}_{\mathbf{p}}$ 。在局部坐标 $\mathbf{z} = (z^1, \dots, z^d)$ 中，它由对称正定矩阵

$G(\mathbf{z}) = [g_{i,j}(\mathbf{z})]$ 表示。坐标速度 $\dot{\mathbf{z}}$ 对应的几何速度长度为

$$\|\dot{\gamma}\|_g^2 = \dot{\mathbf{z}}^\top G(\mathbf{z}) \dot{\mathbf{z}}. \quad (7.13)$$

这里的 G 不是点坐标的协方差矩阵，也不是所有位置共享的距离学习矩阵。它描述每个点处切向速度的局部内积，并且可以随位置变化。

嵌入流形可以继承环境空间的欧氏内积。若 $\mathbf{p} = \varphi(\mathbf{z})$ ，坐标速度 $\dot{\mathbf{z}}$ 在环境空间中对对应 $J_\varphi(\mathbf{z})\dot{\mathbf{z}}$ ，因此诱导度量为

$$G(\mathbf{z}) = J_\varphi(\mathbf{z})^\top J_\varphi(\mathbf{z}). \quad (7.14)$$

Jacobian 矩阵满列秩保证 G 正定。若 Jacobian 矩阵退化，某个非零坐标速度会被映成零，式 (7.14) 只能产生半正定形式，这也说明流形参数化为何要求满秩。

由式 (7.8) 和 (7.9)，弯曲点带的诱导度量为

$$G(s, u) = \begin{bmatrix} (1 + u/R)^2 & 0 \\ 0 & 1 \end{bmatrix}. \quad (7.15)$$

同样的坐标增量 ds 在外侧 $u > 0$ 对应更长圆弧，在内侧 $u < 0$ 对应更短圆弧。坐标数值相同不意味着几何长度相同，度量正是二者之间的换算规则。

7.3.2 路径长度不依赖走路速度和坐标名称

先设分段光滑路径 $\gamma : [a, b] \rightarrow \mathcal{M}$ 的像完全落在一张坐标图内，并在该坐标中写成 $\mathbf{z}(t)$ 。它的长度定义为

$$L_g(\gamma) = \int_a^b \sqrt{\dot{\mathbf{z}}(t)^\top G(\mathbf{z}(t)) \dot{\mathbf{z}}(t)} dt. \quad (7.16)$$

若整条路径不能落在一张坐标图内，就把 $[a, b]$ 分成有限个子区间，使每段路径像位于一张坐标图中，再把各段长度相加。下文的坐标变换计算说明，重叠区域采用哪张图以及怎样进一步细分都不会改变总长度。

参数 t 只规定沿路径前进的方式。若用严格递增的光滑参数 $t = \tau(r)$ 重新参数化，链式法则产生因子 $\tau'(r)$ ，它与 $dt = \tau'(r)dr$ 恰好配对，所以长度不变。停得久或走得快不会改变已经走过的几何路线长度。

坐标变化也不会改变长度。设新坐标为 $\mathbf{v}$ ，旧坐标满足 $\mathbf{z} = \psi(\mathbf{v})$ ，并记 $\mathbf{A} = J_\psi(\mathbf{v})$ 。速度满足 $\dot{\mathbf{z}} = \mathbf{A}\dot{\mathbf{v}}$ 。同一个内积在新坐标中的矩阵必须变为

$$\tilde{G}(\mathbf{v}) = \mathbf{A}^\top G(\psi(\mathbf{v})) \mathbf{A}. \quad (7.17)$$

代入可得

$$\dot{\mathbf{v}}^\top \tilde{\mathbf{G}} \dot{\mathbf{v}} = \dot{\mathbf{z}}^\top \mathbf{G} \dot{\mathbf{z}}.$$

所以式 (7.16) 计算的是几何路径, 而不是某张坐标表上的数字长度。若只换坐标分量却不按式 (7.17) 变换度量, 所得长度就描述了另一个几何问题。

度量只能直接比较同一点切空间中的向量; 沿路径前进时, 不同时刻的速度属于不同切空间, 仍不能直接相减。为定义“方向沿路径怎样变化”, 先令**向量场** (vector field) $\mathbf{V}$ 在每个 $\mathbf{p} \in \mathcal{M}$ 处选取切向量 $\mathbf{V}(\mathbf{p}) \in T_{\mathbf{p}}\mathcal{M}$ 。**联络** (connection) 为两个光滑向量场 $\mathbf{U}, \mathbf{V}$ 指定另一个向量场 $\nabla_{\mathbf{U}}\mathbf{V}$, 称为 $\mathbf{V}$ 沿 $\mathbf{U}$ 的**协变导数** (covariant derivative), 并满足

$$\nabla_{f\mathbf{U}+h\mathbf{W}}\mathbf{V} = f\nabla_{\mathbf{U}}\mathbf{V} + h\nabla_{\mathbf{W}}\mathbf{V}, \quad \nabla_{\mathbf{U}}(a\mathbf{V} + b\mathbf{W}) = a\nabla_{\mathbf{U}}\mathbf{V} + b\nabla_{\mathbf{U}}\mathbf{W},$$

以及 Leibniz 规则

$$\nabla_{\mathbf{U}}(f\mathbf{V}) = \mathbf{U}(f)\mathbf{V} + f\nabla_{\mathbf{U}}\mathbf{V},$$

其中 f, h 为光滑函数, $a, b \in \mathbb{R}$ 。第一条说明求导方向可以按位置变化的系数组合, Leibniz 规则则保留普通导数的乘积法则。

给定 Riemann 度量, 存在唯一同时保持度量且无挠的 **Levi-Civita 联络** (Levi-Civita connection)。“保持度量”与“无挠”分别写成

$$\mathbf{U}(g(\mathbf{V}, \mathbf{W})) = g(\nabla_{\mathbf{U}}\mathbf{V}, \mathbf{W}) + g(\mathbf{V}, \nabla_{\mathbf{U}}\mathbf{W}), \quad \nabla_{\mathbf{U}}\mathbf{V} - \nabla_{\mathbf{V}}\mathbf{U} = [\mathbf{U}, \mathbf{V}],$$

其中 $[\mathbf{U}, \mathbf{V}]$ 是两个方向导数的交换子。沿曲线 γ 的切向量场 $\mathbf{V}(t)$ 的协变导数记作 $D\mathbf{V}/dt$ 。对继承环境欧氏度量的嵌入流形, 它可以直观而准确地写成

$$\frac{D\mathbf{V}}{dt} = \text{proj}_{T_{\gamma(t)}\mathcal{M}} \frac{d\mathbf{V}}{dt};$$

也就是先在环境空间求普通导数, 再只保留当前切空间中的分量。这个定义使后文的“协变加速度为零”不再依赖尚未解释的术语。

7.3.3 测地距离比较流形内允许的路径

若两点 $\mathbf{p}, \mathbf{q} \in \mathcal{M}$ 位于同一路径连通分支, 它们之间的**测地距离** (geodesic distance) 定义为 $\mathcal{M}$ 内所有分段光滑连接路径长度的下确界:

$$d_g(\mathbf{p}, \mathbf{q}) = \inf_{\substack{\gamma(a)=\mathbf{p} \\ \gamma(b)=\mathbf{q}}} L_g(\gamma). \quad (7.18)$$

若不存在连接两点的路径, 则约定 $d_g(\mathbf{p}, \mathbf{q}) = +\infty$; 在整个可能不连通的 $\mathcal{M}$ 上, 这给出的是允许取无穷值的扩展距离。它比较的是被限制在流形上

的行走代价。环境空间欧氏距离允许直接穿过流形外部，所以总有

$$\|\mathbf{p} - \mathbf{q}\|_2 \leq d_g(\mathbf{p}, \mathbf{q})$$

用于欧氏诱导度量的情形。若连接两点的欧氏直线段完全位于流形内，它就给出长度等于弦长的候选路径，因而上式取等。反过来，只有当长度下确界确实由某条允许路径达到时，取等才会迫使该最短路径沿直线段前进，至多相差保持方向的重参数化；下确界不取到时，即使直线段不在流形内，两种距离仍可能相等。

现在可以明确比较中心线与二维带上的距离。取 $\mathbf{p} = \Phi(s, 0)$ 和 $\mathbf{q} = \Phi(t, 0)$ 。若允许路径只能位于一维中心线 $\mathcal{C}$ ，则 s 是弧长参数，并且当前开圆弧上

$$d_{\mathcal{C}}(\mathbf{p}, \mathbf{q}) = |s - t|.$$

若允许路径在二维带 $\mathcal{M}_{\text{strip}}$ 内移动，中心线弧只是一个候选，路径还可以向内侧移动以缩短长度，因此只能一般地写成

$$\|\mathbf{p} - \mathbf{q}\|_2 \leq d_{\mathcal{M}_{\text{strip}}}(\mathbf{p}, \mathbf{q}) \leq d_{\mathcal{C}}(\mathbf{p}, \mathbf{q}) = |s - t|.$$

式 (7.7) 给出左端环境距离；把 $d_{\mathcal{M}_{\text{strip}}}$ 与 $d_{\mathcal{C}}$ 都简称为“沿带距离”会掩盖允许路径的差别。若另把中心线闭合成完整圆， $d_{\mathcal{C}}$ 还要在顺时针和逆时针两段弧长中取较小者。

联络建立以后，可以区分测地线与长度最短测地线。采用仿射参数时，**测地线** (geodesic) 定义为协变加速度为零的曲线：

$$\frac{D\dot{\gamma}}{dt} = \mathbf{0}.$$

白话地说，它的速度沿曲线作平行移动，不产生切向转弯。Levi-Civita 联络在局部坐标中的系数称为 Christoffel 符号：

$$\Gamma_{i,j}^k = \frac{1}{2} \sum_{\ell=1}^d g^{k,\ell} \left(\frac{\partial g_{\ell,j}}{\partial z^i} + \frac{\partial g_{i,\ell}}{\partial z^j} - \frac{\partial g_{i,j}}{\partial z^\ell} \right), \quad (7.19)$$

其中 $[g^{i,j}] = \mathbf{G}^{-1}$ 。测地线条件在坐标中写成

$$\ddot{z}^k + \sum_{i,j=1}^d \Gamma_{i,j}^k(\mathbf{z}) \dot{z}^i \dot{z}^j = 0. \quad (7.20)$$

Christoffel 符号依赖坐标，不是张量；协变导数和式 (7.20) 描述的曲线才是坐标无关对象。

固定端点并对能量

$$E(\gamma) = \frac{1}{2} \int_a^b \dot{\mathbf{z}}^\top \mathbf{G}(\mathbf{z}) \dot{\mathbf{z}} dt$$

应用 Euler-Lagrange 方程, 也会得到式 (7.20)。每条测地线在任一点附近取足够短的一段, 都在该邻域内连接其端点的曲线中长度最短, 但这项局部性质不保证整段曲线在所有连接路径中最短。若一段测地线的长度等于式 (7.18) 的下确界, 就称它为连接两端点的 **长度最短测地线** (length-minimizing geodesic)。越过割点或共轭点, 或者存在更短的绕行路线时, 测地线方程的解仍是测地线, 却未必仍是长度最短测地线。

下确界也不必在任意流形上达到。Hopf-Rinow 定理的一项有限维结论是: 若连通 Riemann 流形关于测地距离完备, 则任意两点之间都存在达到式 (7.18) 的长度最短测地线。完备性不能省略。例如在穿孔平面 $\mathbb{R}^2 \setminus \{\mathbf{0}\}$ 中, 点 $(-1, 0)^\top$ 与 $(1, 0)^\top$ 之间路径长度的下确界为 2, 路径可以任意贴近被删去的原点, 却没有长度恰为 2 的允许路径。因此这里的测地距离仍等于两点的欧氏距离 2, 但直线段不允许且下确界不取到; 这正是上述反向结论需要“下确界达到”条件的原因。局部测地线方程仍可求解, 但它本身不保证全局最短路径存在。

7.3.4 离散近邻路径近似测地距离需要尺度条件

对带噪观测 $\mathbf{x}_i$, 可以把每个样本连接到距离阈值 ε 内的样本, 或连接到 k 个最近邻, 并以 $\|\mathbf{x}_i - \mathbf{x}_j\|_2$ 作为边长。最短边路径试图近似的是所选潜在流形上 $\mathbf{p}_i$ 与 $\mathbf{p}_j$ 之间的测地距离; 潜在模型并不会自动在观测点 $\mathbf{x}_i$ 与 $\mathbf{x}_j$ 之间给出测地距离, 因为观测可能位于所选流形内, 也可能位于其外。潜在对象取 $\mathcal{C}$ 还是 $\mathcal{M}_{\text{strip}}$, 目标距离也随之改变。这里暂时只需要“顶点、边和路径”这些对象; 一般图结构和图算法将在第 4 部分系统建立。

这项近似依赖两个相反要求。邻域要足够小, 使每条边只跨越流形上近似平直的一段, 避免从弯曲点带的一折直接跳到另一折; 邻域又要足够大, 使有限样本之间能够连通。对弯曲点带, 若 ε 超过两折之间的环境间隔, 最短路会产生穿带“捷径”, 系统性低估测地距离。若 ε 小于最大采样空隙, 同一条连续点带又会被拆成多个分支, 距离变为无穷或无法计算。

k 近邻也没有消除这个取舍。稀疏区域中的第 k 个邻居可能很远, 密集区域中的相同 k 又可能只覆盖极小范围; 非均匀采样还会产生方向不对称。要把最短路径收敛为真实测地距离, 需要流形光滑、采样逐渐稠密、噪声受控, 并让邻域尺度随样本量以合适速度缩小。具体降维算法还要说明图构造、边权和误差条件, 不能由“局部距离近似正确”直接推出全局坐标恢复正确。

7.4 平滑能量与几何算子

7.4.1 流形梯度把函数变化转回切向量

设 $f : \mathcal{M} \rightarrow \mathbb{R}$ 为光滑函数。它在 $\mathbf{p}$ 处的微分 $df_{\mathbf{p}}$ 把切向量映为函数的一阶变化，是一个线性泛函。度量允许把这个泛函表示成切向量：**Riemann 梯度** (Riemannian gradient) $\text{grad } f(\mathbf{p}) \in T_{\mathbf{p}}\mathcal{M}$ 由

$$g_{\mathbf{p}}(\text{grad } f, \mathbf{v}) = df_{\mathbf{p}}(\mathbf{v}) \quad \text{对所有 } \mathbf{v} \in T_{\mathbf{p}}\mathcal{M} \quad (7.21)$$

唯一确定。它依赖度量：微分描述同一个线性变化规则，采用不同内积表示时，得到的梯度向量可以不同。

在局部坐标中，令普通偏导数组成 $\nabla_{\mathbf{z}} f = (\partial_1 f, \dots, \partial_d f)^T$ 。若梯度的坐标分量为 $\mathbf{a}$ ，式 (7.21) 要求

$$\mathbf{a}^T \mathbf{G} \mathbf{v} = \nabla_{\mathbf{z}} f^T \mathbf{v}$$

对所有 $\mathbf{v}$ 成立，因此

$$[\text{grad } f]_{\mathbf{z}} = \mathbf{G}^{-1} \nabla_{\mathbf{z}} f. \quad (7.22)$$

不能在弯曲坐标中直接把偏导列表当作几何梯度；逆度量负责把协变量形式的微分转成切向量。

7.4.2 Dirichlet 能量衡量函数沿几何空间的变化

在流形上积分还需要体积元素。度量矩阵把一个小坐标盒的体积缩放为 $\sqrt{\det \mathbf{G}(\mathbf{z})}$ 倍，因此

$$dV_g = \sqrt{\det \mathbf{G}(\mathbf{z})} d\mathbf{z}.$$

函数 f 的**Dirichlet 能量**定义为

$$\mathcal{E}(f) = \frac{1}{2} \int_{\mathcal{M}} \|\text{grad } f\|_g^2 dV_g. \quad (7.23)$$

它累积函数在各个切向方向上的平方变化。常量函数能量为零；函数若只在很短的几何距离内剧烈变化，能量就大。这里“平滑”是相对于度量和体积而言的，不是坐标表上逐坐标变化小的简称。

对弯曲点带，由式 (7.15)，

$$\sqrt{\det \mathbf{G}(s, u)} = 1 + \frac{u}{R}, \quad \mathbf{G}^{-1}(s, u) = \begin{bmatrix} (1 + u/R)^{-2} & 0 \\ 0 & 1 \end{bmatrix}.$$

所以

$$\mathcal{E}(f) = \frac{1}{2} \int \left[\frac{(\partial_s f)^2}{1 + u/R} + \left(1 + \frac{u}{R}\right) (\partial_u f)^2 \right] ds du. \quad (7.24)$$

两个方向的权重来自同一个几何：外侧单位 s 坐标更长，所以相同的 $\partial_s f$ 对应较小的单位几何长度变化；同时外侧的小坐标盒具有更大面积。

7.4.3 能量的一阶变分引出 Laplace–Beltrami 算子

前文的 $\mathcal{M}_{\text{strip}}$ 是无流形边界的开带。为讨论边界积分，另取它的截断闭带

$$\overline{\mathcal{M}}_{\text{strip}} = \{\Phi(s, u) : s \in [s_-, s_+], |u| \leq w\}.$$

它是紧致、具有分片光滑边界的积分域，四个角点的外法向不唯一，但这些点的边界测度为零。以下写带边界公式时， $\mathcal{M}$ 表示这类积分域， $\partial\mathcal{M}$ 表示积分域的边界；函数及所需导数应能从内部延拓到各段边界，从而具有相应的边界迹。

要找到能量下降的方向，令 $f_\epsilon = f + \epsilon h$ ，其中 h 为光滑测试函数。对式 (7.23) 求 $\epsilon = 0$ 处导数，得到

$$\left. \frac{d}{d\epsilon} \mathcal{E}(f + \epsilon h) \right|_{\epsilon=0} = \int_{\mathcal{M}} g(\text{grad } f, \text{grad } h) dV_g. \quad (7.25)$$

流形上的分部积分公式把导数从 h 移到 f ：

$$\int_{\mathcal{M}} g(\text{grad } f, \text{grad } h) dV_g = - \int_{\mathcal{M}} h \Delta_g f dV_g + \int_{\partial\mathcal{M}} h \partial_{\mathbf{n}} f dS_g. \quad (7.26)$$

其中 $\mathbf{n}$ 为边界外法向， $\partial_{\mathbf{n}} f$ 是法向导数， Δ_g 称为 **Laplace–Beltrami 算子** (Laplace–Beltrami operator)。更具体地，若向量场 $\mathbf{V}$ 在局部坐标中的分量为 $V^1, \dots, V^d$ ，其散度定义为

$$\text{div}_g \mathbf{V} = \frac{1}{\sqrt{\det \mathbf{G}}} \sum_{i=1}^d \frac{\partial}{\partial z^i} (\sqrt{\det \mathbf{G}} V^i).$$

取 $\mathbf{V} = \text{grad } f$ 便有 $\Delta_g f = \text{div}_g(\text{grad } f)$ 。它在坐标中的表达式为

$$\Delta_g f = \frac{1}{\sqrt{\det \mathbf{G}}} \sum_{i,j=1}^d \frac{\partial}{\partial z^i} \left(\sqrt{\det \mathbf{G}} g^{i,j} \frac{\partial f}{\partial z^j} \right). \quad (7.27)$$

它是梯度的散度，描述函数值相对于局部几何平均的偏离。

式 (7.26) 也给出变分推导的边界。若积分域改为紧致无边界流形，边界项消失；若固定 f 在边界上的迹，则允许的扰动满足 $h = 0$ ，得到 Dirichlet 边界条件；若边界值自由，能量驻点自然要求 $\partial_{\mathbf{n}} f = 0$ ，得到 Neumann 边界条件。未经说明就删去边界项，等于偷偷选择了问题。截断闭带 $\overline{\mathcal{M}}_{\text{strip}}$ 的边界有两条长边和两个端部；采用哪种条件会改变平滑结果。

若施加相应边界条件使边界项为零，式 (7.25) 表明能量关于 L^2 内积的

梯度是 $-\Delta_g f$ 。因此热方程

$$\frac{\partial f}{\partial t} = \Delta_g f \quad (7.28)$$

沿时间降低 Dirichlet 能量并扩散局部差异。这里的 t 是扩散时间，不是点带坐标 s ；扩散、优化迭代和物理时间在具体模型中可能对应不同对象。

能量恒等式还控制了标量谱。对紧致、光滑、无边界的 Riemann 流形， $-\Delta_g$ 在 $L^2(\mathcal{M}, dV_g)$ 中具有离散非负谱

$$0 = \lambda_0 \leq \lambda_1 \leq \lambda_2 \leq \dots, \quad \lambda_k \rightarrow \infty,$$

并可选取一组光滑特征函数构成 L^2 完备正交系。若 $-\Delta_g \phi = \lambda \phi$ ，由式 (7.26) 取 $h = \phi$ 可得

$$\lambda \int_{\mathcal{M}} \phi^2 dV_g = \int_{\mathcal{M}} \|\text{grad } \phi\|_g^2 dV_g \geq 0,$$

这解释了非负性；离散性与完备性还需要紧致性和椭圆算子理论。流形连通时，零能量迫使 $\text{grad } \phi = \mathbf{0}$ ，故零特征空间恰由常量函数组成。带边界时必须连同边界条件陈述谱：连通域上的 Neumann 条件仍保留常量零模，Dirichlet 条件则使首个特征值严格为正。

7.4.4 采样密度与离散近似不能并入几何定义

从点云构造加权近邻图时，常用相邻函数值差

$$\frac{1}{2} \sum_{i,j} w_{i,j} (f_i - f_j)^2$$

近似连续 Dirichlet 能量。这个式子将在图拉普拉斯建立后由第 4 部分重新推导。此处需要先看清连续对象：流形、度量、体积测度和函数共同决定式 (7.23)。

样本若按非均匀密度 $q(\mathbf{p})$ 取得，简单样本平均更接近对 $q dV_g$ 积分，而不是对几何体积 dV_g 积分。不同的核归一化可能保留这个密度权重，也可能试图消除它，极限算子因而不同。边权非负和矩阵对称只保证某个离散二次型非负，不足以证明它近似指定的 Laplace–Beltrami 算子；还要核对邻域尺度、采样密度、边界处理和归一化。

标量函数的扩散也不能直接替代向量场扩散。前文定义的 Levi–Civita 联络先把不同点处切向量的变化转成协变导数；在此基础上，可以用 $\int_{\mathcal{M}} \|\nabla \mathbf{V}\|_g^2 dV_g$ 衡量向量场变化，并由其变分定义联络拉普拉斯 $\nabla^* \nabla$ 。这里 ∇^* 表示相对于 L^2 内积的伴随；不同文献对拉普拉斯整体符号可能采用相反约定。该构造先规定跨点比较，再累积变化，不能把标量 Laplace–Beltrami 公式逐坐标照搬。第 4 部分建立离散 Dirichlet 能量和图谱时，还

要分别核对边权、归一化与采样密度对应哪个连续算子。

7.5 变换群、不变性与等变性

7.5.1 群作用把抽象变换落实到对象上

坐标可以改变，点带也可以在平面中整体旋转；我们需要区分“变换有哪些代数关系”和“变换具体作用于什么对象”。**群** (group) G 是带有复合运算的集合，满足复合封闭、结合律，具有恒等元 e ，并且每个 $g \in G$ 都有逆元 g^{-1} 。群元素本身可以是旋转、平移、置换或更抽象的变换²。

² J. M. Lee, *Introduction to Smooth Manifolds*, Springer, 2013, 2nd ed.

群作用 (group action) 把每个 $g \in G$ 对应到对象空间 $\mathcal{X}$ 上的变换，记为 $g \cdot x$ ，并要求

$$e \cdot x = x, \quad (g_1 g_2) \cdot x = g_1 \cdot (g_2 \cdot x). \quad (7.29)$$

第二条保证群中的复合与实际连续施加变换一致。只列出若干数据增强而不说明复合后是否仍在允许集合中，通常还没有定义一个群。

线性表示 (linear representation) 是群在向量空间 V 上的线性作用，即映射 $\rho : G \rightarrow \text{GL}(V)$ 满足

$$\rho(e) = I, \quad \rho(g_1 g_2) = \rho(g_1) \rho(g_2). \quad (7.30)$$

输入与输出可以使用不同表示。例如输入点坐标按旋转矩阵变化，标量输出使用 $\rho(g) = 1$ ，向量输出则可使用同一个旋转矩阵。后文写 $F(g \cdot x) = \rho(g)F(x)$ 时， ρ 明确规定的是输出怎样响应，并不要求输出空间与输入空间相同。

二维旋转构成群 $\text{SO}(2)$ 。角度 θ 对应

$$\mathbf{R}(\theta) = \begin{bmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{bmatrix}, \quad \mathbf{R}(\theta_1) \mathbf{R}(\theta_2) = \mathbf{R}(\theta_1 + \theta_2). \quad (7.31)$$

它可作用于单个点、整组点、图像坐标或向量场，但这些是不同的对象空间。对弯曲点带整体旋转时，点坐标变为 $\mathbf{R}(\theta)\Phi(s, u)$ ，内在坐标 (s, u) 可以保持不变。环境坐标改变不等于流形上的点身份或局部坐标必须改变。

有限集合 $\{1, \dots, n\}$ 的全部置换构成对称群 S_n 。若 $\pi \in S_n$ ，其置换矩阵 $\mathbf{P}_\pi$ 可以重排点云矩阵的行。这里改变的是记录顺序，不是把空间中的点移动到另一个几何位置。旋转和重编号都能写成矩阵乘法，却作用在不同索引上，不能因公式外形相似就视为同一种对称。

7.5.2 不变输出忽略变换，等变输出跟随变换

设群 G 作用于输入空间 $\mathcal{X}$ 。函数 $f: \mathcal{X} \rightarrow \mathcal{Y}$ 若满足

$$f(g \cdot x) = f(x) \quad \text{对所有 } g \in G, x \in \mathcal{X}, \quad (7.32)$$

就称为对该作用**不变** (invariant)。它把同一轨道 $\{g \cdot x : g \in G\}$ 上的输入映到相同输出。点带的总长度在整体旋转下不变，点集分类若与记录顺序无关，也应对行置换不变。

若输出空间 $\mathcal{Y}$ 也有一个作用 $\rho(g)$ ，映射 $F: \mathcal{X} \rightarrow \mathcal{Y}$ 满足

$$F(g \cdot x) = \rho(g)F(x), \quad (7.33)$$

就称为**等变** (equivariant)。白话地说，输入怎样变，输出按预先规定的对应方式一起变。对点坐标施加旋转时，返回局部切向量的映射应让切向量也乘 $\mathbf{R}(\theta)$ ；若强迫它保持数值不变，方向就不再对应旋转后的几何对象。

不变性不是比等变性“更强”的统一目标。标量类别、位置坐标、分割掩码和向量场需要的输出行为不同。等变映射后接一个对输出作用不变的汇总，可以得到不变输出；反过来，不变表示已经丢弃轨道内位置，通常无法恢复一个随变换移动的输出。

对点云 $\mathbf{X} \in \mathbb{R}^{n \times d}$ ，逐点共享映射 $F(\mathbf{X})_{i,:} = \phi(\mathbf{X}_{i,:})$ 满足

$$F(\mathbf{P}_\pi \mathbf{X}) = \mathbf{P}_\pi F(\mathbf{X}),$$

所以对行置换等变。再按行求和 $f(\mathbf{X}) = \sum_i \phi(\mathbf{X}_{i,:})$ ，便有 $f(\mathbf{P}_\pi \mathbf{X}) = f(\mathbf{X})$ ，得到置换不变性。这个例子只证明结构关系；求和表示是否足以区分任务需要的点集，还要另行分析。

平移卷积给出另一个可直接核对的等变例子。在整个 $\mathbb{R}^d$ 上定义 $(T_{\mathbf{a}}f)(\mathbf{x}) = f(\mathbf{x} - \mathbf{a})$ ，并设 $k, f \in L^1(\mathbb{R}^d)$ 。卷积积分对几乎处处的 $\mathbf{x}$ 有定义，变量替换给出

$$(k * (T_{\mathbf{a}}f))(\mathbf{x}) = \int_{\mathbb{R}^d} k(\mathbf{x} - \mathbf{y})f(\mathbf{y} - \mathbf{a}) d\mathbf{y} \quad (7.34)$$

$$= (k * f)(\mathbf{x} - \mathbf{a}) = (T_{\mathbf{a}}(k * f))(\mathbf{x}). \quad (7.35)$$

因此理想连续域上的卷积与平移作用对几乎处处的 $\mathbf{x}$ 可交换。若进一步假设相关卷积积分在每个点都绝对收敛，例如一个函数连续且有界、另一个函数可积，则等式可以逐点理解。有限图像若采用零填充，平移后有些值会跨出边界，等式一般不再对全部平移成立；周期边界、有效区域或离散循环平移对应的是不同作用，必须按实际定义重新核对。

7.5.3 群平均可以构造不变函数

对有限群，可以从任意标量函数 $h: \mathcal{X} \rightarrow \mathbb{R}$ 构造

$$\bar{h}(x) = \frac{1}{|G|} \sum_{g \in G} h(g \cdot x). \quad (7.36)$$

对任意 $a \in G$,

$$\bar{h}(a \cdot x) = \frac{1}{|G|} \sum_{g \in G} h((ga) \cdot x).$$

当 g 遍历 G 时, ga 也恰好遍历 G , 所以右端等于 $\bar{h}(x)$ 。这完整证明了群平均的不变性。连续紧群可用保持群平移的 Haar 概率测度把求和改成积分, 但非紧群没有有限均匀概率测度, 不能无条件照搬“对全部平移取平均”。

群平均也会丢失信息。若任务输出必须指出点带朝向, 把所有旋转响应平均成一个标量会消除所需方向。数据增强只在有限样本上鼓励近似关系; 架构等变性则在精确算术和所声明作用下给出结构恒等式。离散网格插值、边界填充和数值误差仍可能破坏连续旋转或平移关系, 实际实现需要按离散对象重新核对。

7.5.4 相对位置来自旋转复合关系

一维平移群可作用于序列位置: 位置同时增加 a 时, 相对位移 $t - s$ 不变。旋转位置编码把标量位置映成若干二维旋转块。对一个频率 ω , 令

$$\mathbf{R}_\omega(t) = \begin{bmatrix} \cos(\omega t) & -\sin(\omega t) \\ \sin(\omega t) & \cos(\omega t) \end{bmatrix}.$$

正交性与旋转复合给出

$$\mathbf{R}_\omega(s)^\top \mathbf{R}_\omega(t) = \mathbf{R}_\omega(t - s). \quad (7.37)$$

因此, 对二维向量 $\mathbf{q}, \mathbf{k}$,

$$(\mathbf{R}_\omega(s)\mathbf{q})^\top (\mathbf{R}_\omega(t)\mathbf{k}) = \mathbf{q}^\top \mathbf{R}_\omega(t - s)\mathbf{k}. \quad (7.38)$$

旋转后的内积只通过相对位移依赖 s, t 。多个频率块并置后仍保持这一性质。

这个推导说明的是位置表示的代数关系, 不表示任意注意力网络都自动只使用相对位置。查询、键之外的偏置、边界处理、截断窗口和其他位置特征都可能引入绝对位置依赖。频率还会带来周期性: 相差某些周期的位置在单个旋转块中无法区分, 需要多频率组合及具体长度范围共同判断。式 (7.37) 是等变结构的依据, 不是无限长度下无碰撞编码的保证。

7.6 局部关系与拓扑信息

7.6.1 局部坐标不能回答连通与环

两条互不相交的圆弧在每个内部点附近都像一条直线，一条闭合圆在每个点附近也像一条直线。它们的局部维数和切空间类型相同，整体关系却不同：前者有两个连通分支，后者只有一个分支并包含一条不可在圆内连续收缩到点的环。研究连续变形下保持的整体性质，需要**拓扑** (topology) 提供不同于长度和角度的语言。

微分几何与拓扑回答的问题不能互相替代。度量可以区分路径长短和曲率尺度，拓扑只关心连续连接、孔洞等在连续变形下是否保留。把弯曲点带整体拉直可能大幅改变环境距离，却不改变其连通性；把开点带的两端粘合成环则改变拓扑，即使粘合处可以做得局部平滑。

有限点本身是离散集合，若不增加邻接规则，每个点都是独立连通分支。要从点云推测连续形状，必须选择一个尺度，把哪些局部关系视为可靠连接。这个尺度是建模条件，不是数据中无条件存在的唯一答案。

7.6.2 单纯复形把点、边和高阶局部关系组合起来

k 维**单纯形** (simplex) 的几何形式，是 $k + 1$ 个仿射独立顶点的凸包；其组合形式只记录这些顶点组成的集合。顶点是零维单纯形，边是一维单纯形，填充三角形是二维单纯形。仿射独立保证几何单纯形确实具有维数 k ，而组合表示用于保留哪些面已被纳入。一个**抽象单纯复形** (abstract simplicial complex) $\mathcal{K}$ 是有限顶点集合上的一族非空子集，并满足向下封闭：

$$\sigma \in \mathcal{K}, \quad \emptyset \neq \tau \subseteq \sigma \implies \tau \in \mathcal{K}. \quad (7.39)$$

因此，加入一个填充三角形时，它的三条边和三个顶点必须同时存在。三条边形成的空心三角环与一个填充三角形拥有相同的一维边图，却具有不同的二维信息；高阶单纯形明确记录局部区域已经被填充，而不是只记录成对接近。

给定点云与边距离尺度 $\varepsilon > 0$ ，一种构造是以每个点为中心放置半径 $\varepsilon/2$ 的欧氏开球。只要一组球有共同交集，就把对应顶点加入同一个单纯形，得到**Čech 复形** (Čech complex)。两点连边表示两个球相交；按这里的开球约定，这等价于两点距离小于 ε 。三个点形成填充三角形则要求三个球具有共同交集。对欧氏空间中的球，这些交集为凸集；在覆盖满足相应良好条件时，神经引理说明复形与球并集具有相同的同伦类型。这个结论解释了组合对象为何可能反映连续覆盖，但它依赖覆盖集合及其交集的条件。

另一种常用构造只要求一个单纯形中的每对顶点距离都不超过给定阈

值, 得到 Vietoris–Rips 复形。它可以由边图直接补全高阶单纯形, 计算更方便, 却不等同于要求全部球有共同交集。两种复形在尺度常数下可以互相夹住, 但不能在同一阈值上不加说明地互换。

7.6.3 边界算子区分环与已经填充的环

要把“首尾相接”和“被一个面填充”分开, 需要记录单纯形的方向。选定顶点次序后, 以 $[v_0, \dots, v_k]$ 表示有向 k 维单纯形; 交换两个顶点会使符号反转。有限个有向 k 维单纯形的实系数线性组合称为 k 维链。边界算子按交替符号删除一个顶点:

$$\partial_k[v_0, \dots, v_k] = \sum_{i=0}^k (-1)^i [v_0, \dots, \widehat{v_i}, \dots, v_k], \quad (7.40)$$

其中尖帽表示删去该顶点, 算子再按线性延伸到全部链。

连续取两次边界总得到零, 即

$$\partial_{k-1}\partial_k = 0. \quad (7.41)$$

证明只需跟踪任意两个被删去的顶点 v_i, v_j 。若先删 v_i 再删 v_j , 与先删 v_j 再删 v_i 会得到同一个 $(k-2)$ 维面; 由于第二次删除时的索引相差一位, 两项符号相反, 因而成对抵消。这个恒等式保证每个高维面的边界本身都没有边界。

满足 $\partial_k c = 0$ 的 k 维链称为**闭链** (cycle), 形象地说, 它没有暴露的端点; 若还存在 $(k+1)$ 维链 b 使 $c = \partial_{k+1} b$, 则 c 称为**边界** (boundary), 表示它已被更高维面填充。边界一定是闭链, 但反向不一定成立, 差别正是同调所记录的孔洞。对三个顶点, 令

$$\mathcal{K}_{\text{loop}} = \{\{1\}, \{2\}, \{3\}, \{1, 2\}, \{2, 3\}, \{1, 3\}\},$$

并取一维链

$$c = [1, 2] + [2, 3] - [1, 3]$$

满足 $\partial_1 c = 0$ 。在 $\mathcal{K}_{\text{loop}}$ 中没有二维单纯形可产生 c , 所以它是未填充的环; 加入 $[1, 2, 3]$ 后, $c = \partial_2[1, 2, 3]$, 同一圈边变成一个面的边界。第 4 部分只用顶点和边建立一般图时, 不能仅凭三条边判断三角区域是否已经填充。

7.6.4 弯曲点带的环会随邻域尺度出现和消失

当前二维开带 $\mathcal{M}_{\text{strip}}$ 与开矩形同胚, 合适的小尺度应沿带形成一个连通的狭长复形, 并在局部三角面填充后不留下贯穿全局的环。若把一维中心线 c 的两端闭合, 得到的对象是圆; 若同时保留横向坐标 u , 二维带则变成环带。两种闭合对象的维数不同, 但都在合适尺度下保留一条绕中心的环。

这条环不是某个单独邻域能够识别的，它由许多局部边沿全局首尾相接形成。

尺度过小时，采样间隙使复形碎成许多连通分支；尺度增大后，相邻样本连接，真实分支逐渐形成；尺度继续增大，跨越点带弯折的边会制造捷径，高阶单纯形还会填平原有环。因而单个尺度上的孔洞既可能来自真实整体结构，也可能来自采样空隙。持续同调等方法会跟踪结构在一系列尺度上的出现与消失，本章只建立其输入对象和判断边界。

前一小节的两个三点复形也说明，顶点数和边数相同仍不足以判断环是否已被填充。Euler 示性数

$$\chi = N_0 - N_1 + N_2 - \dots$$

在前者为 $3 - 3 = 0$ ，后者为 $3 - 3 + 1 = 1$ ，提供了一个粗略整体摘要。不过相同 Euler 示性数也可能对应不同拓扑，不能用一个标量替代连通分支、环和更高维孔洞的分别分析。

7.6.5 模糊关系的强度不是事件概率

硬阈值会让距离略跨过 ε 的一对点从完全连接突然变成完全不连接。另一种做法为边赋予隶属强度 $\mu_{i,j} \in [0, 1]$ ，表示在所选局部尺度下，这对点作为邻接关系的支持程度。高阶单纯形的强度可以由边强度按某种规则组合，例如取最小值；具体组合规则属于构造定义，需要在使用前说明。

两份关系强度还可以用

$$a \sqcup b = a + b - ab, \quad a, b \in [0, 1], \quad (7.42)$$

作为一种“合并”规则。因为 $a + b - ab = 1 - (1 - a)(1 - b)$ ，结果仍在 $[0, 1]$ 内；该运算交换、结合，以 0 为恒等元，并在任一输入为 1 时输出 1。这些代数性质说明它适合作为一种明确定义的软并集，却不表示 a 和 b 已经是两个独立事件的概率。只有先给出随机试验和联合分布，概率加法公式中的乘积项才具有相应解释。

数值落在 $[0, 1]$ 不使 $\mu_{i,j}$ 自动成为概率。概率要求先定义随机试验、事件和概率测度，并满足相应的边缘与联合一致性；模糊隶属度则可以只是“多大程度上属于某种关系”的确定性评分。把局部核权重、相似度、置信度和事件概率都称为概率，会把不同的校准要求和组合规则混在一起。第 3 部分建立概率对象后，才能进一步比较这些解释。

UMAP 等流形学习方法会从局部距离构造带强度的邻接关系，再寻找低维表示以匹配相应关系。本节提供理解这类构造所需的坐标、度量、邻接和模糊组合语言；具体目标、优化过程及误差证据留给第三卷“模型”的“降维”章。低维图像中出现一个分离簇或孔洞，不足以证明原数据具

有对应任务语义,也可能受到邻居数、距离缩放、初始化和优化误差影响。

若需要把局部构造本身作为可复合对象继续抽象,可以使用**范畴**(category)的语言:范畴包含对象、对象之间的箭头、每个对象的恒等箭头以及满足结合律的箭头复合;函子则在保持恒等与复合的前提下把一个范畴映到另一个范畴。这里可以把坐标图、局部关系或它们之间保持结构的映射组织起来,但本章关于距离、能量和单纯边界的推导都不依赖范畴论。这个入口只说明可进一步组合的对象需要遵守什么形式规则,不把抽象名称当作额外结论。

拓扑方法同样不能修复错误的局部关系。若环境距离在弯曲点带两折之间加入大量捷径,复形会忠实组合这些错误边;若采样完全漏掉一段区域,组合对象也无法辨认那里原本应当连接。局部几何估计、采样覆盖和组合尺度共同限定可以支持的整体结论。

7.7 本章小结

弯曲点带说明,几何表示需要持续区分二维带、一维中心线、无噪声潜在点与带噪观测。点间欧氏距离经双重中心化可恢复所给点集的中心化 Gram 矩阵;半正定谱给出欧氏嵌入及其最小维数,但坐标仍可整体平移、旋转或反射。这个过程不会自动从观测距离恢复潜在点。在已有坐标中做 PCA 与从距离重构坐标因此不是同一个问题;中心线测地距离与二维带测地距离也因允许路径不同而不能混用。

流形用局部坐标描述附近自由度,切空间收集潜在点处可实现的一阶速度。坐标分量随坐标图改变,切向量及其几何含义不应改变;局部 PCA 只能在潜在对象、曲率、邻域、密度和噪声条件合适时,从观测估计潜在切方向。Riemann 度量进一步在每个切空间规定长度,路径积分把局部长度连接成整体距离;联络和协变导数则规定怎样比较不同点处的方向,并据此定义测地线。离散近邻最短路只有在既无跨折捷径又保持采样连通时,才可能近似所选潜在流形的测地距离。

同一度量还决定函数平滑性的含义。Riemann 梯度、几何体积和 Dirichlet 能量通过变分关系产生 Laplace-Beltrami 算子,边界条件与采样密度会改变实际平滑问题。离散图能量是这些连续对象的一种近似入口,不是仅凭边权形式就自动成立的对应。

对称性处理的是变换下的关系。群规定变换怎样复合,群作用说明它们怎样改变具体对象;不变映射忽略轨道内变化,等变映射让输出按规定作用同步变化。旋转、平移和节点重编号作用于不同对象,不能只因都可写成矩阵就混为一谈。旋转位置编码的相对位移关系来自旋转复合,但其周期、边界和其他网络部件仍限定最终行为。

局部坐标和切空间看不到整体连通与环,单纯复形通过点、边和高阶面

组合局部关系。所得拓扑依赖采样与尺度，模糊隶属强度也不自动具有概率含义。由此，本章对开篇问题的回答是：弯曲空间不能靠一组全局线性坐标完整描述，需要把局部坐标、切空间、度量、路径、变换和整体连接分别建模，再说明它们如何协作。第 4 部分将把连续平滑与离散图谱连接起来；概率分布上的局部度量则留到信息论与统计几何章节，并继续区分几何接近与任务语义。在此之前，第 8 章将先建立随机变量、条件分布与有限样本误差的共同语言，使“观测到的点带”能够进入统计推断。

第三部分

概率、随机过程与统计

Probability, Stochastic Processes and Statistics

概率论

前两部分研究的对象即使很复杂，给定输入后仍有确定结果。现在考虑一个不同的问题：传感器反复测量同一信号，读数却会受到噪声扰动；学习算法面对有限候选模型，也只能依据有限样本比较它们。单次结果无法代表整体规律，而“多测几次再平均”又留下三个问题：平均的对象是什么，观测增加时平均是否稳定，以及从多个候选中挑出表现最好的一个后，原有误差保证是否仍然成立。

概率论用测度描述结果的不确定性，用积分定义平均，并用条件化表达信息增加后的判断。本章复用第 2 章的测度、积分与极限工具，不再重证单调收敛、控制收敛和 Fubini 定理。我们从有限概率表进入一般概率空间，再沿密度比和条件期望说明“改变分布”与“增加信息”的区别。随后，带噪观测的样本平均贯穿随机收敛、蒙特卡洛估计和集中不等式；有限候选的比较则把单个平均的误差推广为同时误差。章末还会看到，有些有限样本保证不依赖独立性，而来自观测次序的对称性。

8.1 概率空间与随机变量

8.1.1 从有限概率表到事件测度

设一次带噪观测只能取有限个结果 $\Omega = \{\omega_1, \dots, \omega_m\}$ ，并为每个结果指定权重 $p_j \geq 0$ ，满足 $\sum_{j=1}^m p_j = 1$ 。事件 $A \subseteq \Omega$ 的概率为

$$\mathbb{P}(A) = \sum_{\omega_j \in A} p_j.$$

这个有限公式已经包含三条基本规则：概率非负，全集概率为 1，互不相交事件的概率可以相加。一般样本空间可能不可数，而且未必希望给每个子集都赋概率。第 2 章的测度语言恰好把这三条规则推广到这种情形。

概率空间 (probability space) 是三元组 $(\Omega, \mathcal{F}, \mathbb{P})$ 。其中， Ω 是所有可能结果组成的样本空间， $\mathcal{F}$ 是事件组成的 σ 代数， $\mathbb{P} : \mathcal{F} \rightarrow [0, 1]$ 是满足

$\mathbb{P}(\Omega) = 1$ 的测度。可数可加性说明，对两两不交的事件 $(A_j)_{j \geq 1}$,

$$\mathbb{P}\left(\bigcup_{j \geq 1} A_j\right) = \sum_{j \geq 1} \mathbb{P}(A_j).$$

概率不是附着在口头描述上的数，而是定义在指定事件族上的测度。若改变 $\mathcal{F}$ ，能够询问的事件也会改变。

对事件 A ，其补事件和单调性分别给出

$$\mathbb{P}(A^c) = 1 - \mathbb{P}(A), \quad A \subseteq B \implies \mathbb{P}(A) \leq \mathbb{P}(B).$$

概率测度还与单调极限相容。若 $A_n \uparrow A$ ，令 $B_1 = A_1$ 、 $B_n = A_n \setminus A_{n-1}$ ，则 (B_n) 两两不交且 $A = \bigcup_n B_n$ 。可数可加性因而给出

$$\mathbb{P}(A) = \sum_{n \geq 1} \mathbb{P}(B_n) = \lim_{n \rightarrow \infty} \mathbb{P}(A_n).$$

若 $A_n \downarrow A$ ，对补事件使用上一结论便得到 $\mathbb{P}(A_n) \rightarrow \mathbb{P}(A)$ 。第二个结论用到了 $\mathbb{P}(A_1) \leq 1 < \infty$ ；对一般无限测度，递减连续性必须另外要求起始集合具有有限测度。

对任意可数事件族，即使事件不互斥，也有联合界

$$\mathbb{P}\left(\bigcup_{j \geq 1} A_j\right) \leq \sum_{j \geq 1} \mathbb{P}(A_j). \quad (8.1)$$

第 8.11 节会用它同时控制有限候选的误差。

8.1.2 随机变量把结果变成可计算的数

给定可测空间 $(\mathcal{X}, \mathcal{A})$ ，若映射 $X : \Omega \rightarrow \mathcal{X}$ 满足 $X^{-1}(B) \in \mathcal{F}$ 对每个 $B \in \mathcal{A}$ 成立，就称 X 为取值于 $\mathcal{X}$ 的**随机变量** (random variable)。对实值变量，只需验证

$$\{\omega : X(\omega) \leq x\} \in \mathcal{F}, \quad x \in \mathbb{R},$$

因为这些半无限区间生成 $\mathcal{B}(\mathbb{R})$ 。可测性保证由取值范围定义的原像确实属于 $\mathcal{F}$ ，因而有概率。随机变量不是“本身会随机变化的符号”，而是把基础结果转换成所关心对象的可测函数。

X 在实数轴上诱导的概率测度称为它的**分布** (distribution)：

$$\mathbb{P}_X(B) = \mathbb{P}(X \in B), \quad B \in \mathcal{B}(\mathbb{R}).$$

分布函数

$$F_X(x) = \mathbb{P}(X \leq x)$$

单调不减、右连续, 并满足 $\lim_{x \rightarrow -\infty} F_X(x) = 0$ 与 $\lim_{x \rightarrow \infty} F_X(x) = 1$ 。反过来, 每个具有这些性质的函数都对应某个实随机变量的分布。

若 $\mathbb{P}_X$ 集中在可数点集上, 可写成概率质量函数 $p_X(x) = \mathbb{P}(X = x)$ 。若它相对于 Lebesgue 测度有密度 f_X , 则

$$\mathbb{P}(X \in B) = \int_B f_X(x) dx, \quad F_X(x) = \int_{-\infty}^x f_X(t) dt.$$

密度值不是单点概率。连续分布通常满足 $\mathbb{P}(X = x) = 0$, 但 $f_X(x)$ 仍可为正; 它描述的是小邻域概率除以邻域长度后的局部极限。例如 X 在区间 $[0, 1/4]$ 上均匀分布时, $f_X(x) = 4\mathbb{I}\{0 \leq x \leq 1/4\}$ 。密度值 4 可以大于 1, 因为概率由面积而非高度给出: $\mathbb{P}(0.10 \leq X \leq 0.15) = 4 \times 0.05 = 0.2$, 而每个单点的概率仍为 0。

8.1.3 期望是分布下的积分

对非负随机变量 X , 定义

$$\mathbb{E}[X] = \int_{\Omega} X(\omega) d\mathbb{P}(\omega).$$

对一般实随机变量, 写 $X = X^+ - X^-$ 。当 $\mathbb{E}[|X|] < \infty$ 时, 正负两部分积分都有限, 此时称 X 可积, 并定义 $\mathbb{E}[X] = \mathbb{E}[X^+] - \mathbb{E}[X^-]$ 。不要求可积便随意相减 $\infty - \infty$ 没有意义。

期望只依赖 X 的分布。对可测函数 g , 只要 $g(X)$ 非负或可积, 就有

$$\mathbb{E}[g(X)] = \int_{\mathbb{R}} g(x) d\mathbb{P}_X(x). \quad (8.2)$$

离散时右侧是 $\sum_x g(x)p_X(x)$, 有密度时则是 $\int g(x)f_X(x)dx$ 。这条“无须先求 $g(X)$ 分布”的积分公式, 会反复用于矩、蒙特卡洛估计和分布变换。

式 (8.2) 直接来自推送测度的定义。对指示函数 $g = \mathbb{I}_B$, 等式两侧分别为 $\mathbb{P}(X \in B)$ 与 $\mathbb{P}_X(B)$, 所以相等。线性地把结论推广到非负简单函数; 任取递增到非负可测 g 的简单函数列, 再在两侧使用单调收敛定理, 即得非负情形。可积实值函数则分别对 g^+ 和 g^- 应用这一结论。这个证明同时说明, 等式并不要求 X 有密度。

示例 8.1 带噪观测的平均目标 设未知信号为 θ , 观测为

$$Y = \theta + \varepsilon, \quad \mathbb{E}[\varepsilon] = 0.$$

只要 ε 可积, 就有 $\mathbb{E}[Y] = \theta$ 。这并未说明一次读数接近 θ , 也未说明多个读数的平均必然收敛; 后者还需要抽样依赖关系和矩条件。概

率模型先把目标写成分布下的平均，后续误差结论再回答有限观测能否逼近这个平均。

8.2 绝对连续、密度与测度变换

8.2.1 零集兼容性先于密度比

在有限集合上，两个概率表 (p_j) 与 (q_j) 可以逐项比较。若想用 P 下的样本计算 Q 下的平均，候选权重自然是 q_j/p_j 。但当 $p_j = 0$ 而 $q_j > 0$ 时， P 永远不会产生第 j 个结果，任何有限权重都无法补回这部分质量。

这一障碍在一般空间中由**绝对连续** (absolute continuity) 刻画。对同一可测空间上的测度 ν 与 μ ，若

$$\mu(A) = 0 \implies \nu(A) = 0, \quad A \in \mathcal{F},$$

就记作 $\nu \ll \mu$ 。它只要求 μ 的零集也是 ν 的零集，并不表示 $\nu(A) \leq \mu(A)$ ，也不自动提供有界的密度比。

8.2.2 有限分割上的密度表示

先考虑有限分割 $\Omega = A_1 \dot{\cup} \dots \dot{\cup} A_m$ ，并假设 $\nu \ll \mu$ 。对 $\mu(A_j) > 0$ 的分块定义

$$r(\omega) = \frac{\nu(A_j)}{\mu(A_j)}, \quad \omega \in A_j;$$

在 $\mu(A_j) = 0$ 的分块上令 $r = 0$ 。绝对连续性保证后一类分块也满足 $\nu(A_j) = 0$ 。因此，对任意由这些分块组成的事件 A ，

$$\nu(A) = \int_A r \, d\mu.$$

对分块上为常数的函数 g ，逐项相加还给出

$$\int_{\Omega} g \, d\nu = \int_{\Omega} g r \, d\mu. \quad (8.3)$$

一般定理要做的事，是在没有预先给定有限分块时构造同样的 r ¹。

定理 8.2 Radon–Nikodym 定理 设 μ 与 ν 是 $(\Omega, \mathcal{F})$ 上的 σ 有限测度，且 $\nu \ll \mu$ 。则存在非负可测函数 r ，使每个 $A \in \mathcal{F}$ 都满足

$$\nu(A) = \int_A r \, d\mu. \quad (8.4)$$

¹ O. Kallenberg, *Foundations of Modern Probability*, Springer, 2021, 3rd ed.

函数 r 在 μ -几乎处处意义下唯一, 记为 $r = \mathrm{d}\nu/\mathrm{d}\mu$, 称为**Radon-Nikodym 导数** (Radon-Nikodym derivative)。

证明. 先设 μ, ν 有限, 并令 $\lambda = \mu + \nu$. 在线性空间 $L^2(\lambda)$ 上定义

$$T(f) = \int f \, \mathrm{d}\nu.$$

由于 $\nu \leq \lambda$, Cauchy-Schwarz 不等式给出

$$|T(f)| \leq \int |f| \, \mathrm{d}\nu \leq \nu(\Omega)^{1/2} \left(\int f^2 \, \mathrm{d}\nu \right)^{1/2} \leq \nu(\Omega)^{1/2} \|f\|_{L^2(\lambda)}.$$

因此 T 是有界线性泛函。由第4章的 Riesz 表示定理, 存在 $g \in L^2(\lambda)$, 使

$$\int f \, \mathrm{d}\nu = \int f g \, \mathrm{d}\lambda, \quad f \in L^2(\lambda).$$

取 $f = \mathbb{1}_A$ 可得 $\nu(A) = \int_A g \, \mathrm{d}\lambda$. 若 $A = \{g < 0\}$ 具有正测度, 则对集合 $\{g \leq -1/k\}$ 取指示函数会得到 $\nu(\{g \leq -1/k\}) < 0$ 的矛盾, 故 $g \geq 0$ 几乎处处。又因为 $\mu(A) = \lambda(A) - \nu(A) = \int_A (1 - g) \, \mathrm{d}\lambda \geq 0$, 同理有 $g \leq 1$ 几乎处处。

令 $C = \{g = 1\}$. 在 C 上有 $\mu(C) = \int_C (1 - g) \, \mathrm{d}\lambda = 0$, 而 $\nu \ll \mu$ 推出 $\nu(C) = 0$. 另一方面, $\nu(C) = \int_C g \, \mathrm{d}\lambda = \lambda(C)$, 所以 $\lambda(C) = 0$. 于是可以在其余部分定义

$$r = \frac{g}{1 - g},$$

并在 C 上任取值。由 $\mathrm{d}\mu = (1 - g) \, \mathrm{d}\lambda$, 对每个 $A \in \mathcal{F}$ 都有

$$\int_A r \, \mathrm{d}\mu = \int_A \frac{g}{1 - g} (1 - g) \, \mathrm{d}\lambda = \int_A g \, \mathrm{d}\lambda = \nu(A).$$

若 r_1, r_2 都满足该表示, 则对 $A_k = \{r_1 \geq r_2 + 1/k\}$ 有

$$0 = \int_{A_k} (r_1 - r_2) \, \mathrm{d}\mu \geq \frac{1}{k} \mu(A_k),$$

故 $\mu(A_k) = 0$. 对 k 取并集得到 $r_1 \leq r_2$ 几乎处处; 交换二者即得唯一性。

对 σ 有限的 μ, ν , 分别取有限测度覆盖并求交, 可以把 Ω 写成可数个互不相交、在两种测度下均有限的可测分块。在每个分块上使用上述构造, 再把各块导数拼接, 便得到全空间上的 r 。拼接后的表示可先对有限个分块验证, 再由单调收敛推广到全部分块。 ■

这个证明先让 $\lambda = \mu + \nu$ 同时支配两种测度, 再把测度 ν 表示为 $L^2(\lambda)$ 中的函数 g 。绝对连续性只用于排除 $g = 1$ 承载正质量, 保证比值 $g/(1 - g)$

能够成为相对于 μ 的密度。构造得到的是可测密度，并没有得到逐点上界。

8.2.3 换测度与权重风险

定理 8.3 换测度积分公式 若 $\nu \ll \mu$, $r = d\nu/d\mu$, 则对每个非负可测函数 g ,

$$\int g d\nu = \int gr d\mu.$$

只要 g 在 ν 下可积，同一等式也对实值 g 成立。

证明. 对指示函数 $g = \mathbb{I}_A$, 结论就是 Radon–Nikodym 表示。由线性性，它对非负简单函数成立。任取非负可测 g , 选择简单函数 $g_n \uparrow g$, 分别在 ν 和 μ 下使用单调收敛定理即可。对可积实值函数，再分别处理 g^+ 与 g^- 。■

密度比存在、有界和具有有限二阶矩是三项不同条件。若 $P \ll Q$, 则 $w = dP/dQ$ 存在且 $\mathbb{E}_Q[w] = 1$, 但这不推出 $\|w\|_\infty < \infty$, 也不推出 $\mathbb{E}_Q[w^2] < \infty$ 。例如在 $(0, 1)$ 上令 Q 为均匀分布，取

$$w(x) = \frac{1}{2\sqrt{x}}.$$

它的积分为 1，所以定义一个 $P \ll Q$; 但 w 无界，且 $\int_0^1 w(x)^2 dx = \infty$ 。换测度恒等式仍成立，使用该权重的蒙特卡洛估计却可能没有有限方差。

有限表可以直接核对权重方向。设参考分布 Q 在三个结果上的概率为 $(0.5, 0.4, 0.1)$ ，目标分布 P 为 $(0.2, 0.3, 0.5)$ ，则

$$w = \frac{dP}{dQ} = (0.4, 0.75, 5).$$

对取值 $g = (1, 2, 4)$ ，有

$$\mathbb{E}_P[g] = 2.8 = 0.5(0.4)(1) + 0.4(0.75)(2) + 0.1(5)(4) = \mathbb{E}_Q[wg].$$

第三个结果在 Q 下少见，却在 P 下承载一半质量，所以产生大权重。若把参考概率 0.1 改成 0 而保持目标概率 0.5，则 $P \not\ll Q$ ，任何重加权都无法从 Q 样本恢复这部分目标质量。

绝对连续性也决定几乎处处结论能否转移。若 $P \ll Q$ ，且 $|g| \leq M$ 在 Q 下几乎处处成立，则违背上界的集合是 Q -零集，因而也是 P -零集；同一上界在 P 下仍成立。反向转移需要 $Q \ll P$ ，不能只凭 $P \ll Q$ 得到。若 $|g| \leq B$ ，则

$$\mathbb{E}_Q[w^2 g^2] \leq B^2 \mathbb{E}_Q[w^2],$$

所以权重二阶矩有限是有界被积函数获得有限重加权方差的充分条件。把

权重截为 $w_c = \min\{w, c\}$ 会限制波动, 但 $\mathbb{E}_Q[w_c g]$ 与 $\mathbb{E}_P[g]$ 之差为 $-\mathbb{E}_Q[(w-c)_+ g]$, 一般不为零。

8.3 联合、边缘与条件分布

8.3.1 联合分布同时描述多个随机量

随机向量 (X, Y) 的联合分布是映射 $\omega \mapsto (X(\omega), Y(\omega))$ 在乘积空间上诱导的概率测度。离散情形中, 联合质量 $p_{X,Y}(x, y)$ 给出完整表格, 边缘分布由求和消去另一坐标:

$$p_X(x) = \sum_y p_{X,Y}(x, y), \quad p_Y(y) = \sum_x p_{X,Y}(x, y).$$

若联合分布有密度, 则相应运算变为

$$f_X(x) = \int f_{X,Y}(x, y) dy.$$

一般情形不需要质量函数或密度。记坐标投影为 $\pi_X(x, y) = x$, 则边缘分布就是联合分布经 π_X 的推送:

$$\mathbb{P}_X(A) = \mathbb{P}_{(X,Y)}(A \times \mathcal{Y}).$$

对非负可测函数 g , 式 (8.2) 给出

$$\int g(x) \mathbb{P}_X(dx) = \int g(\pi_X(x, y)) \mathbb{P}_{(X,Y)}(dx, dy).$$

若联合分布有密度, 再对右侧使用 Tonelli 定理, 才得到对 y 积分的边缘密度公式。因而“边缘化”首先是测度推送, 求和或积分只是它在特定参考测度下的表达。

边缘化会丢掉变量如何共同变化的信息。两个不同联合分布可以拥有完全相同的两个边缘分布。

当 $p_X(x) > 0$ 时, 离散条件质量定义为

$$p_{Y|X}(y | x) = \frac{p_{X,Y}(x, y)}{p_X(x)}.$$

因此有乘法公式

$$p_{X,Y}(x, y) = p_X(x) p_{Y|X}(y | x).$$

若 $p_Y(y) > 0$, 把联合质量按另一顺序分解便得到 Bayes 公式

$$p_{X|Y}(x | y) = \frac{p_{Y|X}(y | x) p_X(x)}{\sum_{x'} p_{Y|X}(y | x') p_X(x')}. \quad (8.5)$$

分母是观测 y 的边缘概率，既负责归一化，也要求观测并非零概率事件。

连续密度公式是同一分解的特例。若 (X, Y) 相对于乘积参考测度有联合密度 $f_{X,Y}$ ，且 $f_X(x) > 0$ ，则

$$f_{Y|X}(y|x) = \frac{f_{X,Y}(x,y)}{f_X(x)}$$

非负并对 y 积分为 1。它满足 $f_{X,Y}(x,y) = f_X(x)f_{Y|X}(y|x)$ 。在 $f_X(x) = 0$ 的点上，这个比值没有定义；正则条件分布可以在那里任取一个概率测度，而不改变联合分布。

示例 8.4 有限候选经过带噪观测更新 设信号只可能是 $\Theta \in \{-1, 1\}$ ，先验概率均为 $1/2$ 。传感器以概率 0.8 报告正确符号。观测 $Y = 1$ 后，

$$\mathbb{P}(\Theta = 1 | Y = 1) = \frac{0.8 \times 0.5}{0.8 \times 0.5 + 0.2 \times 0.5} = 0.8.$$

观测并未把候选集合改成一个确定点，而是改变了两个候选的相对权重。若某个观测在所有候选下概率都为零，公式分母为零，条件分布不能靠这个比值定义。

8.3.2 概率核让条件值连续变化

当条件变量连续时，事件 $\{X = x\}$ 常有零概率，直接相除不再可行。更合适的对象是**概率核** (probability kernel)

$$K : \mathcal{X} \times \mathcal{B}(\mathcal{Y}) \rightarrow [0, 1].$$

它同时满足两项要求：固定 x 时， $K(x, \cdot)$ 是 $\mathcal{Y}$ 上的概率测度；固定可测集 B 时， $x \mapsto K(x, B)$ 可测。第一项保证每个条件值给出合法分布，第二项保证再对 X 积分是合法运算。

若联合分布满足

$$\mathbb{P}(X \in A, Y \in B) = \int_A K(x, B) \mathbb{P}_X(dx), \quad (8.6)$$

就把 $K(x, \cdot)$ 称为 Y 给定 $X = x$ 的一个**正则条件分布** (regular conditional distribution)。两个版本只需在 $\mathbb{P}_X$ -几乎处处意义下相同；零概率条件点上的取值通常不能由联合分布唯一决定。

8.3.3 正则条件分布何时存在

若 X 与 Y 的状态空间都是**标准 Borel 空间** (standard Borel space)，则上述正则条件分布存在。标准 Borel 空间是与某个完备可分度量空间的 Borel

子集在可测结构上同构的空间；“可分”表示该度量空间含有可数稠密子集。实数空间、欧氏空间、可数集合以及配备适当 Borel 结构的常见可分函数空间都属于这一范围。

构造思路可以从可数生成族看清。先在 $\mathcal{Y}$ 的一个可数、能区分概率测度的集合族上，对每个 B 构造 $\mathbb{P}(Y \in B \mid \sigma(X))$ ；再选取这些条件期望关于 X 的可测版本。在去掉一个共同零测集后，这些数值满足有限可加性和连续性，扩张定理把它们唯一延拓为 $\mathcal{Y}$ 上的概率测度。标准 Borel 结构提供的可数性和可分性，正是把逐个事件的版本整理成同一个概率核所需的条件。

在完全一般的可测空间上，正则条件分布可能不存在。此时条件期望仍可相对于子 σ 代数定义，但不能未经说明就把它写成每个点 x 上的条件密度。后续模型通常工作在标准 Borel 空间中；使用 $p(y \mid x)$ 时，应同时确认密度所依赖的参考测度及其适用的几乎处处范围。

8.4 期望、方差与条件期望

8.4.1 矩描述平均位置与波动

可积随机变量的均值记作 $\mu_X = \mathbb{E}[X]$ 。若 $\mathbb{E}[X^2] < \infty$ ，其方差为

$$\text{Var}(X) = \mathbb{E}[(X - \mu_X)^2] = \mathbb{E}[X^2] - \mu_X^2.$$

对二阶可积的 X, Y ，协方差为

$$\text{Cov}(X, Y) = \mathbb{E}[(X - \mathbb{E}X)(Y - \mathbb{E}Y)].$$

Cauchy-Schwarz 不等式保证它有限。方差满足

$$\text{Var}(aX + b) = a^2 \text{Var}(X),$$

而

$$\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y) + 2 \text{Cov}(X, Y).$$

只有协方差为零时，方差才直接相加；独立是协方差为零的充分条件，但通常不是必要条件。

8.4.2 条件期望只保留当前信息

子 σ 代数 $\mathcal{G} \subseteq \mathcal{F}$ 表示当前可用信息。对可积随机变量 X ，**条件期望** (conditional expectation) $\mathbb{E}[X \mid \mathcal{G}]$ 是满足下列两项条件的随机变量 Z ：

$$Z \text{ 对 } \mathcal{G} \text{ 可测}, \quad \int_A Z \, d\mathbb{P} = \int_A X \, d\mathbb{P} \quad (A \in \mathcal{G}).$$

第一项要求答案只能使用 $\mathcal{G}$ 中的信息，第二项要求它在每个可由当前信息识别的事件上保留 X 的平均²。

定理 8.5 条件期望的存在与唯一性 若 $X \in L^1(\mathbb{P})$ ，则 $\mathbb{E}[X | \mathcal{G}]$ 存在，并在几乎处处意义下唯一。

² O. Kallenberg, *Foundations of Modern Probability*, Springer, 2021, 3rd ed.

证明. 先设 $X \geq 0$ 。在 $(\Omega, \mathcal{G})$ 上定义有限测度

$$\nu(A) = \int_A X \, d\mathbb{P}.$$

若 $\mathbb{P}(A) = 0$ ，则 $\nu(A) = 0$ ，所以 $\nu \ll \mathbb{P}|_{\mathcal{G}}$ 。Radon-Nikodym 定理给出非负、 $\mathcal{G}$ -可测的 Z ，使 $\nu(A) = \int_A Z \, d\mathbb{P}$ 。对一般可积 X ，分别对 X^+ 与 X^- 使用这一构造并取差，即得存在性。

若 Z_1, Z_2 都满足定义，令 $D = Z_1 - Z_2$ 。对每个 $A \in \mathcal{G}$ ， $\int_A D \, d\mathbb{P} = 0$ 。若 $\mathbb{P}(D > 0) > 0$ ，则某个集合 $A_k = \{D \geq 1/k\}$ 具有正概率，从而

$$\int_{A_k} D \, d\mathbb{P} \geq \frac{1}{k} \mathbb{P}(A_k) > 0,$$

产生矛盾。因此 $D \leq 0$ 几乎处处。交换 Z_1, Z_2 可得 $D \geq 0$ 几乎处处，故二者几乎处处相等。 ■

若 X 本来就对 $\mathcal{G}$ 可测，则 $\mathbb{E}[X | \mathcal{G}] = X$ 几乎处处。若 X 与 $\mathcal{G}$ 独立，则条件期望等于常数 $\mathbb{E}[X]$ 。若 U 有界且 $\mathcal{G}$ -可测，则

$$\mathbb{E}[UX | \mathcal{G}] = U\mathbb{E}[X | \mathcal{G}]. \quad (8.7)$$

可积的非有界 U 需要另外核对乘积可积性，不能仅凭“已知量可提出”略去条件。

有限分组把抽象定义化成逐组平均。若 $A_1, \dots, A_m$ 是有限可测分割， $\mathcal{G} = \sigma(A_1, \dots, A_m)$ ，且每个 $\mathbb{P}(A_j) > 0$ ，则

$$\mathbb{E}[X | \mathcal{G}] = \sum_{j=1}^m \frac{\mathbb{E}[X \mathbb{I}_{A_j}]}{\mathbb{P}(A_j)} \mathbb{I}_{A_j}. \quad (8.8)$$

若某个分组概率为零，该组上的取值可以任意指定，因为条件期望只在几乎处处意义下唯一。

表 8.1 给出一个可复核例子。令 $\mathcal{G}$ 只能区分 $A = \{\omega_1, \omega_2\}$ 与 $B = \{\omega_3, \omega_4\}$ 。不使用分组信息时，最佳常数预测是 $U_0 = \mathbb{E}X = 3.4$ ；规则 U_{grp} 虽然按组取值，却随意地在 A, B 上分别预测 0, 4；条件均值 $m = \mathbb{E}[X | \mathcal{G}]$ 则在两组上分别等于 1.2, 5.6。三列风险依次说明不同问题：获得分组信息可以优于

结果	概率	X	分组	U_0	U_{grp}	m
ω_1	0.2	0	A	3.4	0	1.2
ω_2	0.3	2	A	3.4	0	1.2
ω_3	0.1	4	B	3.4	4	5.6
ω_4	0.4	6	B	3.4	4	5.6
平方风险 $\mathbb{E}[(X - U)^2]$				5.64	2.80	0.80

表 8.1 有限分组下的三类预测。分组信息使预测可以随 A, B 变化，但只有逐组条件均值在全部 $\mathcal{G}$ -可测平方可积预测中达到最小平方风险。

无信息常数，但使用信息本身不保证已经最优；式 (8.8) 还要在每组内选择正确的条件平均。

8.4.3 塔式性质与全期望

定理 8.6 塔式性质 若 $X \in L^1$ ，且 $\mathcal{H} \subseteq \mathcal{G} \subseteq \mathcal{F}$ ，则

$$\mathbb{E}[\mathbb{E}[X | \mathcal{G}] | \mathcal{H}] = \mathbb{E}[X | \mathcal{H}]$$

几乎处处成立。

证明. 左侧对 $\mathcal{H}$ 可测。对任意 $A \in \mathcal{H}$ ，由于 $A \in \mathcal{G}$ ，条件期望定义给出

$$\int_A \mathbb{E}[\mathbb{E}[X | \mathcal{G}] | \mathcal{H}] d\mathbb{P} = \int_A \mathbb{E}[X | \mathcal{G}] d\mathbb{P} = \int_A X d\mathbb{P}.$$

左侧因而满足 X 关于 $\mathcal{H}$ 的条件期望定义，唯一性给出结论。 ■

取 $\mathcal{H} = \{\emptyset, \Omega\}$ ，便得到**全期望公式** (law of total expectation)

$$\mathbb{E}[\mathbb{E}[X | \mathcal{G}]] = \mathbb{E}[X]. \quad (8.9)$$

这说明条件化改变可用信息，却不改变再平均后的总体均值。

8.4.4 全方差分解

设 $X \in L^2$ ，记 $m = \mathbb{E}[X | \mathcal{G}]$ 。分解

$$X - \mathbb{E}X = (X - m) + (m - \mathbb{E}X).$$

在展开平方前，需要先确认条件均值仍然二阶可积。对凸函数 $u \mapsto u^2$ 使用条件 Jensen 不等式，有

$$|m|^2 \leq \mathbb{E}[X^2 | \mathcal{G}].$$

再取期望并使用全期望公式，得到

$$\mathbb{E}[m^2] \leq \mathbb{E}[X^2] < \infty.$$

因此 $m \in L^2$ ，上面分解中的两项都二阶可积，其乘积由 Cauchy-Schwarz 不等式保证可积。又因为第二项对 $\mathcal{G}$ 可测，而 $\mathbb{E}[X - m | \mathcal{G}] = 0$ ，所以交叉项期望为

$$\mathbb{E}[(X - m)(m - \mathbb{E}X)] = \mathbb{E}[(m - \mathbb{E}X)\mathbb{E}[X - m | \mathcal{G}]] = 0.$$

展开平方得到**全方差公式** (law of total variance)

$$\text{Var}(X) = \mathbb{E}[\text{Var}(X | \mathcal{G})] + \text{Var}(\mathbb{E}[X | \mathcal{G}]), \quad (8.10)$$

其中

$$\text{Var}(X | \mathcal{G}) = \mathbb{E}[(X - m)^2 | \mathcal{G}].$$

第一项是获得 $\mathcal{G}$ 后仍无法解释的平均波动，第二项是不同信息状态之间的可解释波动。

8.4.5 平方损失下的最佳预测

定理 8.7 条件均值的平方损失最优性 设 $X \in L^2(\mathbb{P})$ 。在所有 $\mathcal{G}$ -可测且二阶可积的随机变量 U 中，

$$m = \mathbb{E}[X | \mathcal{G}]$$

唯一地在几乎处处意义下最小化 $\mathbb{E}[(X - U)^2]$ 。

证明. $L^2(\mathcal{G})$ 是 $L^2(\mathcal{F})$ 的闭线性子空间，上文的条件 Jensen 不等式已经说明 $m \in L^2(\mathcal{G})$ 。对每个 $U \in L^2(\mathcal{G})$ ，Cauchy-Schwarz 不等式保证 $(X - m)U$ 可积，因而可以提出已知因子并使用塔式性质，得到

$$\mathbb{E}[(X - m)U] = \mathbb{E}[U\mathbb{E}[X - m | \mathcal{G}]] = 0.$$

所以 $X - m$ 与整个 $L^2(\mathcal{G})$ 正交。定理 4.1 说明 m 是 X 到该闭子空间的正交投影。也可直接展开

$$\mathbb{E}[(X - U)^2] = \mathbb{E}[(X - m)^2] + \mathbb{E}[(m - U)^2], \quad (8.11)$$

交叉项因正交性消失。第二项非负，且仅当 $U = m$ 几乎处处时为零。 ■

条件期望的存在只需要 $X \in L^1$ ，这时它由 Radon-Nikodym 导数给出。“正交投影”和平方损失最优性则需要 $X \in L^2$ 。若二阶矩无限，条件

期望仍可能存在，但不能使用 Hilbert 空间几何或有限平方风险。

8.4.6 条件换测度

设 $Q \ll P$ ，并记 $L = dQ/dP$ 。对 $X \in L^1(Q)$ ，在 $\mathbb{E}_P[L | \mathcal{G}] > 0$ 处有

$$\mathbb{E}_Q[X | \mathcal{G}] = \frac{\mathbb{E}_P[LX | \mathcal{G}]}{\mathbb{E}_P[L | \mathcal{G}]} \quad (8.12)$$

为验证这个候选变量确实是条件期望，记

$$D = \mathbb{E}_P[L | \mathcal{G}], \quad N = \mathbb{E}_P[LX | \mathcal{G}],$$

并在 $\{D > 0\}$ 上令 $Z = N/D$ ，在 $\{D = 0\}$ 上令 $Z = 0$ 。分母零集在 Q 下可以忽略，因为

$$Q(D = 0) = \mathbb{E}_P[L \mathbb{I}\{D = 0\}] = \mathbb{E}_P[D \mathbb{I}\{D = 0\}] = 0.$$

条件期望的单调性还给出

$$|N| \leq \mathbb{E}_P[L|X| | \mathcal{G}].$$

在 $\{D = 0\}$ 上，非负变量 $L \mathbb{I}\{D = 0\}$ 的期望为零，因而 $L = 0$ 几乎处处。于是

$$\mathbb{E}_P[\mathbb{E}_P[L|X| | \mathcal{G}] \mathbb{I}\{D = 0\}] = \mathbb{E}_P[L|X| \mathbb{I}\{D = 0\}] = 0,$$

上面的条件三角不等式进而说明 $N = 0$ 在 $\{D = 0\}$ 上几乎处处成立。因此 $DZ = N$ 几乎处处，而且

$$\begin{aligned} \mathbb{E}_Q[Z] &= \mathbb{E}_P[L|Z|] = \mathbb{E}_P[D|Z|] \\ &= \mathbb{E}_P[|N| \mathbb{I}\{D > 0\}] \leq \mathbb{E}_P[L|X|] = \mathbb{E}_Q|X| < \infty. \end{aligned}$$

这里把 $\mathcal{G}$ -可测的非负因子 $|Z|$ 提出条件期望，可以由有界截断和单调收敛得到。候选变量的可积性建立后，对 $A \in \mathcal{G}$ 可合法地计算

$$\begin{aligned} \int_A Z dQ &= \int_A ZL dP = \int_A Z \mathbb{E}_P[L | \mathcal{G}] dP \\ &= \int_A \mathbb{E}_P[LX | \mathcal{G}] dP = \int_A LX dP = \int_A X dQ. \end{aligned}$$

因此 Z 满足 X 在 Q 下关于 $\mathcal{G}$ 的条件期望定义。公式(8.12)是 Bayes 更新的一般测度形式；分母零集与候选变量可积性都需要像上面这样核对。

用有限分组可以看出分母为何不可省略。设参考分布 P 把四个结果 $\omega_1, \dots, \omega_4$ 分别赋予概率 $(0.4, 0.1, 0.1, 0.4)$ ，目标分布 Q 赋予 $(0.1, 0.4, 0.2, 0.3)$ 。令信息 $\mathcal{G}$ 只区分 $A = \{\omega_1, \omega_2\}$ 和 A^c ，并令 $X = (0, 1, 0, 1)$ 。权重 L 在四点

上的值为 $(0.25, 4, 2, 0.75)$ 。在 A 内,

$$\mathbb{E}_P[LX | \mathcal{G}] = \frac{0.4}{0.5} = 0.8, \quad \mathbb{E}_P[L | \mathcal{G}] = \frac{0.1 + 0.4}{0.5} = 1,$$

所以目标条件均值为 0.8, 与 $\mathbb{E}_Q[X | A] = 0.4/(0.1 + 0.4)$ 一致。直接用某个无条件权重乘 $\mathbb{E}_P[X | A] = 0.2$ 不会得到目标条件均值; 条件化后必须在每个信息分组内重新归一化。

8.5 高阶矩、独立性与条件独立

8.5.1 不相关没有排除非线性依赖

若随机变量 X, Y 满足

$$\mathbb{P}(X \in A, Y \in B) = \mathbb{P}(X \in A)\mathbb{P}(Y \in B)$$

对所有 Borel 集合 A, B 成立, 就称二者**独立** (independent)。独立意味着所有可积可分函数都满足 $\mathbb{E}[g(X)h(Y)] = \mathbb{E}[g(X)]\mathbb{E}[h(Y)]$ 。证明从指示函数开始: 独立性正好说明结论对 $g = \mathbb{I}_A, h = \mathbb{I}_B$ 成立。线性性把它推广到简单函数, 随后分别用单调收敛处理非负函数, 再分解正负部分处理乘积可积的实值函数。这里必须要求相关积分有定义, 不能把两个发散期望形式相乘。

协方差只检查中心化变量的一次乘积。令 X 在 $[-1, 1]$ 上均匀分布, 并取 $Y = X^2$ 。对称性给出

$$\text{Cov}(X, Y) = \mathbb{E}[X^3] - \mathbb{E}[X]\mathbb{E}[X^2] = 0,$$

但 Y 由 X 完全决定; 知道 X 便能确定 Y , 所以二者不独立。零协方差只排除了线性二阶关联。

8.5.2 高阶矩与累积量

若 $\mathbb{E}[|X|^k] < \infty$, 则 $\mathbb{E}[X^k]$ 称为 k 阶原点矩, $\mathbb{E}[(X - \mathbb{E}X)^k]$ 称为 k 阶中心矩。三阶中心矩反映不对称性, 四阶中心矩反映尾部与峰度, 但有限低阶矩通常不能唯一确定分布。

在 origin 附近存在时, **矩母函数** (moment-generating function, MGF) 为

$$M_X(t) = \mathbb{E}[e^{tX}].$$

若可在积分号下求导, 则 $M_X^{(k)}(0) = \mathbb{E}[X^k]$ 。矩存在不保证矩母函数在 origin 邻域有限; 例如对数正态分布拥有所有正整数阶矩, 却对每个 $t > 0$ 都有 $M_X(t) = \infty$ 。

累积量生成函数 (cumulant-generating function) 是

$$K_X(t) = \log M_X(t).$$

其前两阶导数分别给出均值和方差。对随机向量 $\mathbf{X}$,

$$K_{\mathbf{X}}(\mathbf{t}) = \log \mathbb{E}[e^{t^T \mathbf{X}}],$$

混合偏导数给出联合累积量。独立分量使 $K_{\mathbf{X}}$ 按坐标相加, 因此所有跨分量联合累积量为零。在矩母函数存在的适当邻域内, 反向也可通过解析性得到。独立成分分析利用三阶、四阶等非高斯统计量识别协方差白化后仍隐藏的依赖; 纯高斯变量的三阶以上累积量为零, 不能靠这一路径区分旋转方向。

前两阶关系可以直接核对。若存在 $\delta > 0$ 使 $\mathbb{E}e^{tX} < \infty$ 对 $|t| < \delta$ 成立, 则对更小邻域中的 t , $|X|e^{tX}$ 与 X^2e^{tX} 可由邻域端点的指数函数控制。第2章的积分下求导条件于是给出

$$M'_X(t) = \mathbb{E}[Xe^{tX}], \quad M''_X(t) = \mathbb{E}[X^2e^{tX}].$$

因为 $M_X(0) = 1$,

$$K'_X(0) = \frac{M'_X(0)}{M_X(0)} = \mathbb{E}X, \quad K''_X(0) = M''_X(0) - M'_X(0)^2 = \text{Var}(X).$$

独立变量 X, Y 满足 $M_{X+Y}(t) = M_X(t)M_Y(t)$, 故 $K_{X+Y} = K_X + K_Y$; 累积量可加来自独立性, 而不是仅来自零协方差。

8.5.3 条件独立及其运算规则

给定随机变量 Z , 若对适当的可测集合 A, B ,

$$\mathbb{P}(X \in A, Y \in B \mid Z) = \mathbb{P}(X \in A \mid Z)\mathbb{P}(Y \in B \mid Z)$$

几乎处处成立, 就称 X 与 Y 在给定 Z 时条件独立, 记作 $X \perp Y \mid Z$ 。它表示 Z 已知以后, X 不再提供关于 Y 的额外分布信息; 这不意味着去掉 Z 后仍独立。

条件独立满足以下常用规则:

$$X \perp Y \mid Z \implies Y \perp X \mid Z \quad (\text{对称性}),$$

$$X \perp (Y, W) \mid Z \implies X \perp Y \mid Z \quad (\text{分解}),$$

$$X \perp (Y, W) \mid Z \implies X \perp Y \mid Z, W \quad (\text{弱并}),$$

$$X \perp Y \mid Z, \quad X \perp W \mid Y, Z \implies X \perp (Y, W) \mid Z \quad (\text{收缩}).$$

这些规则可由条件核的乘积分解逐项验证。交性质

$$X \perp Y | Z, W, \quad X \perp W | Z, Y \implies X \perp (Y, W) | Z$$

并非无条件成立；严格为正的有限离散联合质量是一个常用充分条件。若分布把质量集中在低维约束上，零概率组合会阻断所需的消元步骤。

以分解和收缩为例可以看清这些规则使用了什么。若 $X \perp (Y, W) | Z$ ，则对任意可测集合 A, B, C ，条件核满足

$$K_{X,Y,W|Z}(A, B, C | z) = K_{X|Z}(A | z) K_{Y,W|Z}(B, C | z).$$

令 C 取全集便得到 $K_{X,Y|Z} = K_{X|Z} K_{Y|Z}$ ，这就是分解规则。对收缩规则，假设

$$K_{X,Y|Z} = K_{X|Z} K_{Y|Z}, \quad K_{X,W|Y,Z} = K_{X|Y,Z} K_{W|Y,Z}.$$

第一个条件还给出 $K_{X|Y,Z} = K_{X|Z}$ 的一个版本。沿条件乘法公式相乘可得

$$K_{X,Y,W|Z} = K_{X|Z} K_{Y|Z} K_{W|Y,Z} = K_{X|Z} K_{Y,W|Z},$$

即 $X \perp (Y, W) | Z$ 。所有等式都按相应条件变量分布的几乎处处意义理解。概率图模型部分会在这些概率规则之上另加图分离语义；图上没有边本身并不是这里定义的条件独立证明。

多元高斯分布是一个特殊情形：联合高斯随机向量的两个子向量若协方差为零，则它们独立；条件高斯中的条件协方差为零也对应条件独立。这个结论依赖高斯密度由一、二阶矩完全确定，不能推广到一般分布。

8.6 常用分布与分布族

8.6.1 计数、类别与等待时间

Bernoulli 分布以参数 $p \in [0, 1]$ 描述一次二元结果：

$$\mathbb{P}(X = x) = p^x (1 - p)^{1-x}, \quad x \in \{0, 1\},$$

且 $\mathbb{E}X = p$ 、 $\text{Var}(X) = p(1 - p)$ 。 n 个独立同分布的 Bernoulli 变量之和服从**二项分布**

$$\mathbb{P}(S = k) = \binom{n}{k} p^k (1 - p)^{n-k}, \quad k = 0, \dots, n,$$

其均值和方差分别为 np 与 $np(1 - p)$ 。

若一次试验有 K 个类别，概率向量 $\mathbf{p}$ 满足 $p_k \geq 0$ 及 $\sum_k p_k = 1$ 。 n 次独

立试验的类别计数 $\mathbf{N}$ 服从**多项分布**，质量为

$$\mathbb{P}(\mathbf{N} = \mathbf{n}) = \frac{n!}{\prod_{k=1}^K n_k!} \prod_{k=1}^K p_k^{n_k}, \quad \sum_{k=1}^K n_k = n.$$

其均值为 $\mathbb{E}N_k = np_k$ ，协方差为 $\text{Cov}(N_j, N_k) = n(p_j \mathbb{I}\{j = k\} - p_j p_k)$ 。

Poisson 分布以 $\lambda > 0$ 描述固定窗口中的稀疏计数：

$$\mathbb{P}(N = k) = e^{-\lambda} \frac{\lambda^k}{k!}, \quad k = 0, 1, \dots,$$

且均值、方差都为 λ 。若独立计数 $N_j \sim \text{Poisson}(\lambda_j)$ ，则 $\sum_j N_j \sim \text{Poisson}(\sum_j \lambda_j)$ 。

指数分布以速率 $\lambda > 0$ 描述等待时间：

$$f_T(t) = \lambda e^{-\lambda t} \mathbb{I}\{t \geq 0\}.$$

它的均值为 $1/\lambda$ ，方差为 $1/\lambda^2$ ，并具有无记忆性

$$\mathbb{P}(T > s + t \mid T > s) = \mathbb{P}(T > t).$$

无记忆性只适用于已经等待的时长不改变剩余等待分布，不表示不同等待时间自动独立。Poisson 计数与指数等待描述的是同一个齐次到达机制的两个侧面。若速率为 λ 的 Poisson 过程中， $N(t)$ 记录长度为 t 的时间窗内的到达数， T_1 是首次到达时间，则

$$\mathbb{P}(T_1 > t) = \mathbb{P}(N(t) = 0) = e^{-\lambda t}.$$

所以 T_1 服从速率为 λ 的指数分布；独立平稳增量进一步使相邻到达间隔独立同分布。反过来，用独立同分布的指数等待时间累加生成到达时刻，所得计数过程的 $N(t)$ 服从 $\text{Poisson}(\lambda t)$ 。这里的联系依赖齐次性和独立增量，不能由两个边缘分布的名称单独推出。

8.6.2 高斯、Gamma 及概率向量

高斯分布 (Gaussian distribution, 也称正态分布) $X \sim \mathcal{N}(\mu, \sigma^2)$ 具有密度

$$f_X(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left\{-\frac{(x-\mu)^2}{2\sigma^2}\right\}, \quad \sigma^2 > 0.$$

其均值为 μ ，方差为 σ^2 。仿射变换保持高斯性： $aX + b \sim \mathcal{N}(a\mu + b, a^2\sigma^2)$ 。

形状参数 $a > 0$ 、速率参数 $b > 0$ 的**Gamma 分布**密度为

$$f_X(x) = \frac{b^a}{\Gamma(a)} x^{a-1} e^{-bx} \mathbb{I}\{x > 0\}.$$

其均值为 a/b , 方差为 a/b^2 。指数分布是 $a = 1$ 的特例。若使用尺度参数 $\vartheta = 1/b$, 公式会改变; 引用 Gamma 分布时必须说明采用速率还是尺度参数。

若 $U \sim \text{Gamma}(a, 1)$ 与 $V \sim \text{Gamma}(b, 1)$ 独立, 则

$$R = \frac{U}{U+V}$$

服从 **Beta 分布** $\text{Beta}(a, b)$ 。为得到归一化常数, 令 $S = U + V$, 于是 $U = RS$, $V = (1 - R)S$, 变换的 Jacobian 绝对值为 s 。独立 Gamma 密度经过换元得到

$$f_{R,S}(r, s) = \frac{r^{a-1}(1-r)^{b-1}}{\Gamma(a)\Gamma(b)} s^{a+b-1} e^{-s}, \quad 0 < r < 1, s > 0.$$

对 s 积分并使用 Gamma 函数定义, 得到

$$f_R(r) = \frac{\Gamma(a+b)}{\Gamma(a)\Gamma(b)} r^{a-1}(1-r)^{b-1} \mathbb{I}\{0 < r < 1\}.$$

因此

$$\mathbb{E}R = \frac{a}{a+b}, \quad \text{Var}(R) = \frac{ab}{(a+b)^2(a+b+1)}.$$

Beta 分布适合描述 $[0, 1]$ 上的随机比例。这里共同速率使比例与总量分离; 两个 Gamma 变量速率不同则不能直接得到该 Beta 结论。

同样, 若独立变量 $G_k \sim \text{Gamma}(\alpha_k, 1)$, 则归一化比例

$$P_k = \frac{G_k}{\sum_{j=1}^K G_j}$$

服从 **Dirichlet 分布** $\text{Dirichlet}(\alpha_1, \dots, \alpha_K)$ 。其均值为 $\mathbb{E}P_k = \alpha_k/\alpha_0$, 其中 $\alpha_0 = \sum_k \alpha_k$ 。同样令 $S = \sum_k G_k$, 把前 $K-1$ 个比例和总量作为新坐标; Jacobian 为 s^{K-1} 。联合密度分成一个形状为 α_0 的 Gamma 密度和单纯形上的

$$f_{\mathbf{P}}(\mathbf{p}) = \frac{\Gamma(\alpha_0)}{\prod_{k=1}^K \Gamma(\alpha_k)} \prod_{k=1}^K p_k^{\alpha_k-1}.$$

由 Beta 边缘或直接积分可得

$$\text{Var}(P_k) = \frac{\alpha_k(\alpha_0 - \alpha_k)}{\alpha_0^2(\alpha_0 + 1)}, \quad \text{Cov}(P_j, P_k) = -\frac{\alpha_j \alpha_k}{\alpha_0^2(\alpha_0 + 1)} \quad (j \neq k).$$

负协方差来自各坐标之和固定为 1。例如 $\text{Beta}(8, 2)$ 的均值为 0.8、方差为 $16/1100 \approx 0.0145$; $\text{Beta}(80, 20)$ 均值仍为 0.8, 方差降为 $1600/1010000 \approx 0.00158$ 。参数总量增大使质量更集中, 却不表示已经观察到相同比例的真实频数; 参数如何由数据更新属于第 10 章的统计推断问题。Beta 分布是 $K = 2$ 时对一个坐标的描述。

8.6.3 指数族与对数配分函数

在可测空间上固定一个 σ 有限参考测度 μ 。一类由 η 索引的分布若都被 μ 支配, 且能写成

$$\frac{dP_\eta}{d\mu}(x) = h(x) \exp\{\eta^\top T(x) - A(\eta)\}, \quad (8.13)$$

就称为**指数族** (exponential family)。其中 η 是自然参数, $T(x)$ 是充分统计量, $h(x)$ 是基准项。这里“充分”可以先理解为: 样本取值中与参数 η 有关的部分只通过摘要 $T(x)$ 进入密度; 对独立同分布样本, 相应摘要为 $\sum_i T(x_i)$ 。充分性的正式定义与判据留到第10章。负责归一化的对数配分函数为

$$A(\eta) = \log \int h(x) e^{\eta^\top T(x)} d\mu(x),$$

自然参数空间由该积分有限的参数组成。离散分布通常取计数测度, 此时积分就是求和; 连续分布通常取 Lebesgue 测度。因而 Poisson 分布与高斯分布都能由同一形式描述, 但使用的参考测度不同。

若 η 位于自然参数空间内部, 并存在可积控制函数允许交换微分与积分, 则

$$\begin{aligned} \nabla A(\eta) &= \frac{\int T(x) h(x) e^{\eta^\top T(x)} d\mu(x)}{\int h(x) e^{\eta^\top T(x)} d\mu(x)} \\ &= \mathbb{E}_\eta[T(X)]. \end{aligned}$$

再求一次导数得到

$$\nabla^2 A(\eta) = \text{Cov}_\eta(T(X)). \quad (8.14)$$

协方差矩阵半正定, 所以 A 凸。若某个充分统计量方向几乎处处为其他方向的线性组合, Hessian 矩阵可能奇异, 严格凸性并不自动成立。

以 Poisson 分布为例,

$$p_\lambda(x) = \frac{1}{x!} \exp\{x \log \lambda - \lambda\}.$$

自然参数为 $\eta = \log \lambda$, 充分统计量为 $T(x) = x$, $A(\eta) = e^\eta$ 。于是

$$A'(\eta) = e^\eta = \mathbb{E}X, \quad A''(\eta) = e^\eta = \text{Var}(X),$$

与 Poisson 分布的均值、方差一致。

Bernoulli 分布提供另一个核对。令 $\eta = \log(p/(1-p))$, 则

$$p_\eta(x) = \exp\{x\eta - \log(1 + e^\eta)\}, \quad x \in \{0, 1\}.$$

所以 $A(\eta) = \log(1 + e^\eta)$, $A'(\eta) = p$, $A''(\eta) = p(1-p)$ 。对方差已知的高斯分布, $\eta = \mu/\sigma^2$, $T(x) = x$, 而 $A(\eta) = \sigma^2 \eta^2/2$, 省略的基准项包含

$\exp\{-x^2/(2\sigma^2)\}$ 。于是 $A'(\eta) = \mu$ 、 $A''(\eta) = \sigma^2$ 。这些例子说明，产生均值和协方差的是 $\log$ 配分函数 A 的导数，不是未取对数的归一化常数本身。

8.7 随机向量与分布变换

8.7.1 多元高斯的线性与条件结构

d 维**随机向量** (random vector) 是从基础概率空间到 $(\mathbb{R}^d, \mathcal{B}(\mathbb{R}^d))$ 的可测映射；这个名称不包含坐标独立假设。若各坐标二阶可积，随机向量 $\mathbf{X}$ 的均值和协方差分别为

$$\boldsymbol{\mu} = \mathbb{E}\mathbf{X}, \quad \boldsymbol{\Sigma} = \mathbb{E}[(\mathbf{X} - \boldsymbol{\mu})(\mathbf{X} - \boldsymbol{\mu})^\top].$$

对任意 $\mathbf{u} \in \mathbb{R}^d$,

$$\mathbf{u}^\top \boldsymbol{\Sigma} \mathbf{u} = \mathbb{E}[(\mathbf{u}^\top (\mathbf{X} - \boldsymbol{\mu}))^2] \geq 0,$$

所以协方差矩阵总是对称半正定。若 $\mathbf{Y} = \mathbf{A}\mathbf{X} + \mathbf{b}$ ，线性性给出

$$\mathbb{E}\mathbf{Y} = \mathbf{A}\boldsymbol{\mu} + \mathbf{b}, \quad \text{Cov}(\mathbf{Y}) = \mathbf{A}\boldsymbol{\Sigma}\mathbf{A}^\top.$$

这两条结论只要求相应矩存在，不要求 $\mathbf{X}$ 服从高斯分布。

若对每个 $\mathbf{u} \in \mathbb{R}^d$ ，标量 $\mathbf{u}^\top \mathbf{X}$ 都服从一维高斯分布，就称 $\mathbf{X}$ 为**多元高斯随机向量** (multivariate Gaussian random vector)。这个定义允许某些线性组合方差为零，此时相应高斯分布退化为常数。若其协方差 $\boldsymbol{\Sigma}$ 正定，多元高斯密度为

$$p(\mathbf{x}) = \frac{1}{(2\pi)^{d/2} \det(\boldsymbol{\Sigma})^{1/2}} \exp\left\{-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu})\right\}.$$

奇异协方差仍定义高斯分布，但它集中在低维仿射子空间上，不具有相对于 d 维 Lebesgue 测度的密度。

若 $\mathbf{X} \sim \mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ ，则

$$\mathbf{A}\mathbf{X} + \mathbf{b} \sim \mathcal{N}(\mathbf{A}\boldsymbol{\mu} + \mathbf{b}, \mathbf{A}\boldsymbol{\Sigma}\mathbf{A}^\top).$$

把向量与协方差分块为

$$\mathbf{X} = \begin{bmatrix} \mathbf{X}_1 \\ \mathbf{X}_2 \end{bmatrix}, \quad \boldsymbol{\Sigma} = \begin{bmatrix} \boldsymbol{\Sigma}_{11} & \boldsymbol{\Sigma}_{12} \\ \boldsymbol{\Sigma}_{21} & \boldsymbol{\Sigma}_{22} \end{bmatrix},$$

边缘 $\mathbf{X}_1$ 仍为 $\mathcal{N}(\boldsymbol{\mu}_1, \boldsymbol{\Sigma}_{11})$ 。若 $\boldsymbol{\Sigma}_{22}$ 可逆，配方或第 6 章的 Schur 补运算给出

$$\begin{aligned} \mathbf{X}_1 \mid \mathbf{X}_2 = \mathbf{x}_2 &\sim \mathcal{N}(\boldsymbol{\mu}_1 + \boldsymbol{\Sigma}_{12}\boldsymbol{\Sigma}_{22}^{-1}(\mathbf{x}_2 - \boldsymbol{\mu}_2), \\ &\quad \boldsymbol{\Sigma}_{11} - \boldsymbol{\Sigma}_{12}\boldsymbol{\Sigma}_{22}^{-1}\boldsymbol{\Sigma}_{21}). \end{aligned} \quad (8.15)$$

条件均值是观测的仿射函数，条件协方差不依赖具体观测值。若分块协方差奇异，需要使用广义逆并在支持子空间上解释条件分布，不能直接套用逆矩阵公式。

式(8.15)也可由一个独立残差推导。令

$$\mathbf{R} = \mathbf{X}_1 - \boldsymbol{\mu}_1 - \boldsymbol{\Sigma}_{12}\boldsymbol{\Sigma}_{22}^{-1}(\mathbf{X}_2 - \boldsymbol{\mu}_2).$$

直接计算得到 $\text{Cov}(\mathbf{R}, \mathbf{X}_2) = \mathbf{0}$ ，且

$$\text{Cov}(\mathbf{R}) = \boldsymbol{\Sigma}_{11} - \boldsymbol{\Sigma}_{12}\boldsymbol{\Sigma}_{22}^{-1}\boldsymbol{\Sigma}_{21}.$$

$(\mathbf{R}, \mathbf{X}_2)$ 是联合高斯向量，零交叉协方差因而推出独立。给定 $\mathbf{X}_2 = \mathbf{x}_2$ 后， $\mathbf{R}$ 的分布不变，把定义式移项便得到条件均值与条件协方差。

例如令信号 $S \sim \mathcal{N}(0, 4)$ ，观测 $Y = S + \varepsilon$ ，其中 $\varepsilon \sim \mathcal{N}(0, 1)$ 且与 S 独立。于是

$$\text{Cov} \begin{pmatrix} S \\ Y \end{pmatrix} = \begin{bmatrix} 4 & 4 \\ 4 & 5 \end{bmatrix}, \quad S | Y = y \sim \mathcal{N}\left(\frac{4}{5}y, \frac{4}{5}\right).$$

观测到 $y = 2$ 时，条件均值为 1.6，条件方差由先验的 4 降到 0.8。第 16 章的线性高斯滤波会逐时重复这一块条件计算，但还需要动态与观测独立性假设。

8.7.2 Jacobian 矩阵决定连续密度怎样变形

设 $\mathbf{Y} = g(\mathbf{X})$ ，其中 $g: \mathcal{X} \rightarrow \mathcal{Y}$ 为可微双射，逆映射也可微。第 2 章的换元公式给出

$$f_Y(\mathbf{y}) = f_X(g^{-1}(\mathbf{y})) |\det \mathbf{J}_{g^{-1}}(\mathbf{y})|. \quad (8.16)$$

Jacobian 矩阵的行列式补偿局部体积变化。只把 $\mathbf{x} = g^{-1}(\mathbf{y})$ 代入原密度而漏掉该因子，所得函数通常不能积分为 1。

若映射不是一一对应，需要对所有逆像分支求和。例如 $Y = X^2$ 且 X 有密度时，对 $y > 0$ ，

$$f_Y(y) = \frac{f_X(\sqrt{y}) + f_X(-\sqrt{y})}{2\sqrt{y}}.$$

若输出维数低于输入维数，分布可能集中到低维集合，此时不能期待相对于原维度 Lebesgue 测度的普通密度。

8.7.3 混合、潜变量与层次生成

混合模型先抽取离散指标 Z ，再从分量分布生成 X ：

$$p(x) = \sum_{k=1}^K \mathbb{P}(Z = k) p(x | Z = k).$$

边缘化 Z 得到混合密度，条件化 X 则得到分量责任概率。潜变量不必对应可观测的真实类别；它本质上是组织联合分布和计算的数学变量。

混合分布的方差同时包含分量内和分量间变化。若 $\mathbb{P}(Z = 1) = 1/4$ 、 $\mathbb{P}(Z = 2) = 3/4$ ，且

$$X | Z = 1 \sim \mathcal{N}(-1, 1), \quad X | Z = 2 \sim \mathcal{N}(1, 1),$$

则 $\mathbb{E}X = (-1)/4 + 3/4 = 1/2$ 。全方差公式给出

$$\text{Var}(X) = \underbrace{\mathbb{E}[\text{Var}(X | Z)]}_1 + \underbrace{\text{Var}(\mathbb{E}[X | Z])}_{3/4} = \frac{7}{4}.$$

只平均两个分量方差会漏掉均值差造成的 $3/4$ 。

层次模型把参数本身也视为随机变量，例如

$$\Theta \sim \pi, \quad X_i | \Theta \stackrel{\text{ind}}{\sim} p_{\Theta}.$$

给定 Θ 时，观测条件独立；边缘化共同参数后，观测通常相关。把“条件独立”误写成“边缘独立”会丢掉层次模型中共享不确定性的主要作用。

有限 Dirichlet 分布可进一步推广为 **Dirichlet 过程**。在可测空间 $(\mathcal{X}, \mathcal{A})$ 上，先给概率测度空间 $\mathcal{P}(\mathcal{X})$ 配备 **评价 σ 代数**：它由全部映射 $\mu \mapsto \mu(A)$ ， $A \in \mathcal{A}$ ，生成。随机概率测度就是从底层概率空间到这个可测空间的可测映射；换言之，对每个 $A \in \mathcal{A}$ ， $G(A)$ 都必须是随机变量。随机概率测度 $G \sim \text{DP}(\alpha, G_0)$ 满足：对任意有限可测分割 $(A_1, \dots, A_K)$ ，

$$(G(A_1), \dots, G(A_K)) \sim \text{Dirichlet}(\alpha G_0(A_1), \dots, \alpha G_0(A_K)).$$

其中 $\alpha > 0$ 是总质量参数， G_0 是基概率测度；若 $G_0(A_k) = 0$ ，则相应坐标满足 $G(A_k) = 0$ 几乎必然，应删除该零参数坐标后理解 Dirichlet 向量。这一定义通过全部有限分割刻画随机分布，且不同分割上的有限维分布必须在合并分块时相容。相容性与扩张定理给出随机测度的存在，而不是把某一个有限维 Dirichlet 向量直接称为无限维对象。后验、聚类表示及非参数 Bayes 计算留给概率模型章节。

8.7.4 有限轨迹的似然比

考虑长度 T 的轨迹 $\tau = (s_0, a_0, s_1, a_1, \dots, s_T)$ 。在策略 π 下，若初始分布为 ρ ，环境转移核为 P ，则

$$p_\pi(\tau) = \rho(s_0) \prod_{t=0}^{T-1} \pi(a_t | s_t) P(s_{t+1} | s_t, a_t).$$

若目标策略为 π ，采样策略为 μ ，并且两者共享同一初始分布和环境转移核，公共因子相消，得到

$$\frac{p_\pi(\tau)}{p_\mu(\tau)} = \prod_{t=0}^{T-1} \frac{\pi(a_t | s_t)}{\mu(a_t | s_t)}. \quad (8.17)$$

该公式要求目标轨迹分布绝对连续于采样轨迹分布。具体地说，只要 $\pi(a | s) > 0$ ，在可能到达的状态上就需要 $\mu(a | s) > 0$ 。共同环境假设若不成立，转移核的比值也必须保留。即使每一步比值有限，长轨迹连乘仍可能产生极大方差；密度比存在并不提供可用的二阶误差界。

8.8 基础尾界、随机收敛与大样本近似

8.8.1 Markov、Chebyshev 与 Borel–Cantelli 引理

从矩推出收敛关系之前，先建立两条最基本的尾界。若 $X \geq 0$ ，则对 $a > 0$ ，

$$\mathbb{P}(X \geq a) \leq \frac{\mathbb{E}X}{a}. \quad (8.18)$$

证明只需写 $\mathbb{E}X \geq \mathbb{E}[X \mathbb{I}\{X \geq a\}] \geq a\mathbb{P}(X \geq a)$ 。这就是 Markov 不等式。对均值 μ 、方差 $\sigma^2 < \infty$ 的随机变量，把 Markov 不等式用于 $(X - \mu)^2$ ，得到 Chebyshev 不等式

$$\mathbb{P}(|X - \mu| \geq t) \leq \frac{\sigma^2}{t^2}, \quad t > 0. \quad (8.19)$$

它只使用二阶矩，因而适用范围广，但没有利用有界性或指数矩信息。

逐个时刻的尾概率还不足以判断一条样本路径是否反复进入坏事件。记

$$\limsup_{n \rightarrow \infty} A_n = \bigcap_{m=1}^{\infty} \bigcup_{n \geq m} A_n,$$

它表示事件 A_n 发生无穷多次。

定理 8.8 Borel–Cantelli 引理 对事件序列 $(A_n)_{n \geq 1}$ ，有以下两条结论。

1. 若 $\sum_{n=1}^{\infty} \mathbb{P}(A_n) < \infty$, 则 $\mathbb{P}(\limsup_n A_n) = 0$; 这一方向不要求独立。
2. 若事件 $A_1, A_2, \dots$ 相互独立, 且其概率之和发散, 即

$$\sum_{n=1}^{\infty} \mathbb{P}(A_n) = \infty,$$

则 $\mathbb{P}(\limsup_n A_n) = 1$ 。

证明. 对第一条, 联合界给出

$$\mathbb{P}\left(\bigcup_{n \geq m} A_n\right) \leq \sum_{n \geq m} \mathbb{P}(A_n) \longrightarrow 0.$$

而 $\limsup_n A_n$ 包含在每个尾并集中, 故其概率为零。对第二条, 固定 m 。独立性给出

$$\mathbb{P}\left(\bigcap_{n=m}^N A_n^c\right) = \prod_{n=m}^N \{1 - \mathbb{P}(A_n)\} \leq \exp\left\{-\sum_{n=m}^N \mathbb{P}(A_n)\right\} \longrightarrow 0.$$

因此从任意 m 开始至少有一个 A_n 发生的概率都为一; 再对可数个 m 取交, 便得到 A_n 几乎必然发生无穷多次。 ■

8.8.2 四种收敛控制不同对象

设 X_n, X 定义在同一概率空间上。若对每个 $\varepsilon > 0$,

$$\mathbb{P}(|X_n - X| > \varepsilon) \rightarrow 0,$$

就称 X_n 依概率收敛到 X , 记作 $X_n \rightarrow_{\mathbb{P}} X$ 。它允许小概率坏事件随 n 改变, 只要求每个固定容差外的概率趋于零。

若

$$\mathbb{P}\left(\lim_{n \rightarrow \infty} X_n = X\right) = 1,$$

就称 X_n 几乎必然收敛到 X , 记作 $X_n \rightarrow_{\text{a.s.}} X$ 。它要求除一个固定零测集外, 每条样本路径最终都收敛, 因而比依概率收敛更强。

若 $\mathbb{E}[|X_n - X|^p] \rightarrow 0$, 就称 X_n 在 L^p 中收敛。特别地, $p = 2$ 称为均方收敛。Markov 不等式给出

$$\mathbb{P}(|X_n - X| > \varepsilon) \leq \frac{\mathbb{E}[|X_n - X|^p]}{\varepsilon^p},$$

所以 L^p 收敛蕴含依概率收敛。

若对 X 的每个分布函数连续点 x , 都有

$$F_{X_n}(x) \rightarrow F_X(x),$$

就称 X_n 依分布收敛到 X , 记作 $X_n \Rightarrow X$ 。它只比较边缘分布, 不要求变量定义在同一概率空间上。

主要蕴含关系为

$$X_n \rightarrow_{\text{a.s.}} X \implies X_n \rightarrow_{\mathbb{P}} X \implies X_n \Rightarrow X,$$

以及 L^p 收敛蕴含依概率收敛。前两个蕴含可以直接证明。若 $X_n \rightarrow_{\text{a.s.}} X$, 则对固定 $\varepsilon > 0$, 指示变量 $\mathbb{I}\{|X_n - X| > \varepsilon\}$ 几乎处处趋于 0, 并由常数 1 控制。支配收敛定理给出

$$\mathbb{P}(|X_n - X| > \varepsilon) = \mathbb{E}\mathbb{I}\{|X_n - X| > \varepsilon\} \rightarrow 0.$$

若 $X_n \rightarrow_{\mathbb{P}} X$, 对 F_X 的连续点 x 和任意 $\varepsilon > 0$, 事件包含关系给出

$$F_X(x - \varepsilon) - \mathbb{P}(|X_n - X| > \varepsilon) \leq F_{X_n}(x) \leq F_X(x + \varepsilon) + \mathbb{P}(|X_n - X| > \varepsilon).$$

先令 $n \rightarrow \infty$, 再令 $\varepsilon \downarrow 0$, 由 F_X 在 x 处连续便得 $F_{X_n}(x) \rightarrow F_X(x)$ 。

定理 8.9 Lévy 连续性定理 令 X_n 的特征函数为 $\varphi_n(t) = \mathbb{E}[e^{itX_n}]$ 。若 $\varphi_n(t)$ 对每个 $t \in \mathbb{R}$ 收敛到函数 $\varphi(t)$, 且 φ 在 $t = 0$ 处连续, 则 φ 是某个概率分布的特征函数; 若 X 服从该分布, 则 $X_n \Rightarrow X$ 。反过来, 若 $X_n \Rightarrow X$, 则 $\varphi_n(t) \rightarrow \varphi_X(t)$ 对每个 t 成立。

该定理给出从特征函数逐点极限到依分布收敛的接口。“极限在零点连续”不能省略; 它排除极限质量逃向无穷远而不再对应概率分布的情形。

反向一般不成立。令 $U \sim \text{Unif}(0, 1)$ 并取

$$X_n = \sqrt{n}\mathbb{I}\{U \leq 1/n\}.$$

则 $X_n \rightarrow 0$ 几乎必然且依概率成立, 但 $\mathbb{E}[X_n^2] = 1$, 所以不均方收敛。另一方面, 可以安排概率为 $1/n$ 的独立事件 A_n , 令 $Y_n = \mathbb{I}_{A_n}$ 。此时 $Y_n \rightarrow_{\mathbb{P}} 0$, 但 $\sum_n \mathbb{P}(A_n) = \infty$, 定理 8.8 的第二条说明 A_n 几乎必然发生无穷多次, 故 Y_n 不几乎必然收敛到零。

依分布收敛到常数时可以推出依概率收敛到该常数; 依分布收敛到非退化随机变量则通常不能。若 X 关于原点对称, 令 $X_n = -X$, 则 X_n 与 X 同分布, 却不必有 $|X_n - X| \rightarrow 0$ 。

随机变量族 $\{X_n\}$ 若满足

$$\lim_{K \rightarrow \infty} \sup_n \mathbb{E}[|X_n| \mathbb{I}\{|X_n| > K\}] = 0,$$

就称为**一致可积** (uniformly integrable)。它排除了越来越小概率上的巨大取值仍承载固定期望质量。若 $X_n \rightarrow_{\mathbb{P}} X$ 且 $\{X_n\}$ 一致可积, 则截断函数 $T_K(x) = \max\{-K, \min\{x, K\}\}$ 有界且连续, 故 $T_K(X_n) \rightarrow_{\mathbb{P}} T_K(X)$, 并可从任意子列抽出几乎必然收敛的子列, 再由支配收敛控制截断后的期望。一致可积性与 Fatou 引理还推出 $X \in L^1$, 并控制 X_n 和 X 两端的截断误差。对任意子列重复上述抽取后, 每条子列都有进一步子列在 L^1 中收敛到 X ; 反证法于是得到原序列也在 L^1 中收敛, 即 $\mathbb{E}|X_n - X| \rightarrow 0$ 。没有一致可积性, 例如 $V_n = n\mathbb{I}\{U \leq 1/n\}$ 虽几乎必然趋于 0, 却满足 $\mathbb{E}V_n = 1$, 小概率上的大幅值会阻止期望收敛。

8.8.3 大数定律控制观测平均

定理 8.10 强大数定律 若 $X_1, X_2, \dots$ 独立同分布, 且 $\mathbb{E}[|X_1|] < \infty$, 则

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i \rightarrow_{\text{a.s.}} \mathbb{E}[X_1].$$

强大数定律说明同一分布下的独立重复观测, 其平均几乎必然接近期望。有限方差是许多初等证明使用的方便条件, 但独立同分布版本的结论只需有限一阶绝对矩。若观测相关、分布随时间变化或样本由自适应规则收集, 则不能直接引用该定理; 第 9 章将给出相关过程所需的替代条件³。

有限方差时, 较弱的依概率结论可以在这里完整得到。若 $\text{Var}(X_1) = \sigma^2 < \infty$, 独立性使

$$\text{Var}(\bar{X}_n) = \frac{1}{n^2} \sum_{i=1}^n \text{Var}(X_i) = \frac{\sigma^2}{n}.$$

把式 (8.19) 用于样本平均, 有

$$\mathbb{P}(|\bar{X}_n - \mathbb{E}X_1| \geq \varepsilon) \leq \frac{\sigma^2}{n\varepsilon^2} \rightarrow 0.$$

这证明了有限方差版本的弱大数定律。强大数定律只要求有限一阶绝对矩, 但其证明还需截断大取值、控制截断变量的独立和, 并把可求和坏事件转成几乎必然结论; 不能由上面的逐个 n 概率界直接推出。

³ O. Kallenberg, *Foundations of Modern Probability*, Springer, 2021, 3rd ed.

对例 8.1 中的独立同分布噪声，只要 $\mathbb{E}|\varepsilon_i| < \infty$ ，便有

$$\bar{Y}_n = \theta + \frac{1}{n} \sum_{i=1}^n \varepsilon_i \rightarrow_{\text{a.s.}} \theta.$$

这回答了“多测几次再平均是否稳定”，但没有给出固定 n 时误差超过指定阈值的概率。

8.8.4 中心极限定理描述缩放波动

定理 8.11 Lindeberg-Lévy 中心极限定理 若 $X_1, X_2, \dots$ 独立同分布， $\mathbb{E}X_1 = \mu$ ， $0 < \text{Var}(X_1) = \sigma^2 < \infty$ ，则

$$\frac{\sqrt{n}(\bar{X}_n - \mu)}{\sigma} \Rightarrow \mathcal{N}(0, 1).$$

大数定律研究未缩放误差是否趋于零，中心极限定理研究乘以 $\sqrt{n}$ 后的剩余波动近似什么分布。它给出渐近近似，而不是每个有限 n 都精确服从高斯分布。若方差无限、样本依赖过强或分布随 n 变化而不满足相应 Lindeberg 条件， $\sqrt{n}$ 缩放与高斯极限都可能失效。

证明的关键是特征函数。令 $Y_i = (X_i - \mu)/\sigma$ ，并记 $\varphi(t) = \mathbb{E}e^{itY_1}$ 。复指数绝对值恒为 1，所以特征函数总有定义。由 $\mathbb{E}Y_1 = 0$ 、 $\mathbb{E}Y_1^2 = 1$ 及零点处的二阶展开，

$$\varphi(u) = 1 - \frac{u^2}{2} + o(u^2), \quad u \rightarrow 0.$$

独立性使标准化和的特征函数分解为

$$\mathbb{E} \exp \left\{ it \frac{1}{\sqrt{n}} \sum_{i=1}^n Y_i \right\} = \left[\varphi \left(\frac{t}{\sqrt{n}} \right) \right]^n \rightarrow e^{-t^2/2}.$$

右侧是标准高斯的特征函数，并且在零点连续。定理 8.9 于是给出依分布收敛。第 10 章会用这个渐近分布构造近似区间，但有限样本覆盖仍需额外误差控制，不能只引用极限式。

8.9 蒙特卡洛平均与方差控制

8.9.1 同一积分的直接平均

目标积分可统一写成

$$I = \mathbb{E}_P[f(X)].$$

若能独立采样 $X_i \sim P$, 直接蒙特卡洛估计为

$$\hat{I}_n = \frac{1}{n} \sum_{i=1}^n f(X_i).$$

当 $\mathbb{E}_P|f(X)| < \infty$ 时, 大数定律给出一致性; 当方差 $\sigma_f^2 < \infty$ 时,

$$\text{Var}(\hat{I}_n) = \frac{\sigma_f^2}{n}, \quad \sqrt{n}(\hat{I}_n - I) \Rightarrow \mathcal{N}(0, \sigma_f^2).$$

误差的标准差按 $n^{-1/2}$ 下降, 与输入维数没有显式关系, 但 σ_f^2 可能随问题结构急剧增大。

以下固定教学积分

$$I = \int_0^1 x^2 dx = \frac{1}{3}.$$

若 $X \sim \text{Unif}(0, 1)$, 直接平均 X_i^2 的单样本方差为

$$\text{Var}(X^2) = \frac{1}{5} - \frac{1}{9} = \frac{4}{45}.$$

8.9.2 重要性采样改变采样分布

若 $P \ll Q$, 权重 $w = dP/dQ$, 则

$$I = \mathbb{E}_Q[w(X)f(X)].$$

从 Q 采样得到无偏估计

$$\hat{I}_n^{\text{IS}} = \frac{1}{n} \sum_{i=1}^n w(X_i)f(X_i), \quad X_i \sim Q. \quad (8.20)$$

无偏性只要求乘积可积; 有限方差还要求 $\mathbb{E}_Q[w^2 f^2] < \infty$ 。

对上述积分, 取 Q 的密度 $q(x) = 2x$, 而 P 为均匀分布。除零测点 $x = 0$ 外, $w(x) = 1/(2x)$, 于是 $w(x)f(x) = x/2$ 。单样本方差变为

$$\mathbb{E}_Q \left[\frac{X^2}{4} \right] - \frac{1}{9} = \frac{1}{8} - \frac{1}{9} = \frac{1}{72},$$

小于直接平均的 $4/45$ 。这次改进来自 Q 把更多样本放到 x^2 贡献较大的区域。并非任意改变分布都会降低方差; 若 Q 在重要区域过轻, 权重尾部反而会放大误差。

这个例子背后有一个理想基准。对固定的被积函数 f , 无偏改写其实不要求整个 $P \ll Q$, 只要求 Q 支配有符号测度 $f dP$: 若 $Q(A) = 0$, 则 $\int_A |f| dP = 0$ 。当 P, Q 相对于同一测度分别有密度 p, q 时, 这等价于

$q(x) > 0$ 在 $|f(x)|p(x) > 0$ 处几乎处处成立。此时令

$$h_Q(x) = \frac{f(x)p(x)}{q(x)}, \quad q(x) > 0,$$

便有 $I = \mathbb{E}_Q[h_Q(X)]$ 。若 $0 < \mathbb{E}_P|f(X)| < \infty$ ，则在满足这一支配条件的提议密度中，使 $\mathbb{E}_Q[h_Q^2]$ 最小的选择满足

$$q^*(x) = \frac{|f(x)|p(x)}{\mathbb{E}_P|f(X)|}.$$

它把采样质量直接放到被积函数绝对贡献大的区域。若 $f(x) = 0$ 而 $p(x) > 0$ ，则 $q^*(x) = 0$ ，所以一般并没有 $P \ll Q^*$ ，密度比 p/q^* 也不必在该点定义；但该点对 $f \, dP$ 没有贡献，而且不会被 Q^* 采到，只需把 h_{Q^*} 定义到 Q^* -几乎处处即可。特别地，当 $f \geq 0$ 时， $q^* = fp/I$ ，且 $h_{Q^*}(X) = I$ 在 Q^* 下几乎处处成立，理论方差为零。

这个分布通常不能直接执行：归一化常数就是未知积分 I ，而从 fp/I 精确采样也可能与原问题一样困难。若还要用同一组权重估计其他被积函数，因而必须保留 $P \ll Q$ ，可以取 $q_\eta = (1-\eta)q^* + \eta p$ ，其中 $0 < \eta < 1$ ；混入的 p 为所有 P -正质量区域保留严格正支持。理想分布因此只提供设计直觉；实际提议分布还必须能够归一化、采样并计算密度，同时覆盖 $|f|p$ 非零的区域。

8.9.3 控制变量利用已知平均

若辅助变量 $h(X)$ 的均值 μ_h 已知，则对任意 β ，

$$f_\beta(X) = f(X) - \beta(h(X) - \mu_h)$$

仍有期望 I 。其方差为

$$\text{Var}(f_\beta) = \text{Var}(f) - 2\beta \text{Cov}(f, h) + \beta^2 \text{Var}(h).$$

当 $\text{Var}(h) > 0$ 时，最优系数为

$$\beta^* = \frac{\text{Cov}(f, h)}{\text{Var}(h)}.$$

对 $f(X) = X^2$ 、 $h(X) = X$ 与均匀 X ，有 $\mu_h = 1/2$ 且 $\beta^* = 1$ 。调整后的变量

$$X^2 - X + \frac{1}{2}$$

仍以 $1/3$ 为均值，方差降为 $1/180$ 。实际用同一批数据估计 β^* 时，有限样本无偏性和方差公式需要重新核对；把估计系数当成固定常数会忽略额外随机性。

8.9.4 Rao-Blackwell 条件化去掉无用噪声

设 Y 是目标 I 的无偏估计, $\mathbb{E}[Y^2] < \infty$ 。对某个统计量 T 定义

$$Y^* = \mathbb{E}[Y | T].$$

全期望公式给出 $\mathbb{E}Y^* = I$, 全方差公式给出

$$\text{Var}(Y) = \mathbb{E}[\text{Var}(Y | T)] + \text{Var}(Y^*) \geq \text{Var}(Y^*). \quad (8.21)$$

这就是 Rao-Blackwell 化: 在保持均值的同时, 对已知信息求条件平均, 消去条件内噪声。

仍以 $I = 1/3$ 为例。独立生成 $X, U \sim \text{Unif}(0, 1)$, 令

$$Y = \mathbb{I}\{U \leq X^2\}.$$

则 $\mathbb{E}Y = 1/3$, 而 $\mathbb{E}[Y | X] = X^2$ 。因此直接平均 X^2 可以看成命中估计 Y 关于 X 的 Rao-Blackwell 化, 方差从 $(1/3)(2/3) = 2/9$ 降为 $4/45$ 。

8.9.5 自归一化权重的收益与代价

设 $P \ll Q$, 但只能在未知公共常数倍的意义下计算目标密度比, 即对某个 $c > 0$,

$$\tilde{w}(x) = c \frac{dP}{dQ}(x),$$

在 Q -几乎处处意义下成立。对独立同分布样本 $X_i \sim Q$, 在分母为正时使用 $\tilde{w}_i = \tilde{w}(X_i)$ 并定义

$$\hat{I}_n^{\text{SN}} = \frac{\sum_{i=1}^n \tilde{w}_i f(X_i)}{\sum_{i=1}^n \tilde{w}_i}. \quad (8.22)$$

它是两个随机平均的比值, 通常在有限样本下有偏, 因为一般而言 $\mathbb{E}[A/B] \neq \mathbb{E}A/\mathbb{E}B$ 。在适当矩条件和分母极限为正时, 大数定律仍可给出一致性。更具体地, 若 $\mathbb{E}_Q[|\tilde{w}f|] < \infty$ 且 $0 < \mathbb{E}_Q[\tilde{w}] < \infty$, 则强大数定律给出

$$\hat{I}_n^{\text{SN}} \longrightarrow \frac{\mathbb{E}_Q[\tilde{w}f]}{\mathbb{E}_Q[\tilde{w}]} = \frac{c\mathbb{E}_P[f]}{c} = I \quad \text{几乎必然.}$$

若 $\tilde{w}$ 不是目标密度比的公共常数倍, 同一比值仍可能收敛, 但极限一般对应另一个归一化加权分布, 不能据此声称估计的是 $\mathbb{E}_P[f]$ 。

一个三点分布可以同时看清方差、截断与重采样的不同作用。令支持集为 $\{a, b, c\}$, 提议分布和目标分布分别为

$$Q = (0.8, 0.15, 0.05), \quad P = (0.4, 0.3, 0.3),$$

于是重要性权重为 $w = (0.5, 2, 6)$ 。对 $f = (0, 1, 1)$, 目标均值为 $I = 0.6$ 。原

始单样本贡献 $Z = wf = (0, 2, 6)$ 满足

$$\mathbb{E}_Q Z = 0.6, \quad \text{Var}_Q(Z) = \{0.15 \times 4 + 0.05 \times 36\} - 0.6^2 = 2.04.$$

因此 n 个独立样本的无偏估计方差为 $2.04/n$ 。若把权重截断在 2, 则 $w^{(2)} = (0.5, 2, 2)$, 相应贡献的期望变为 0.4, 方差变为

$$\{0.15 \times 4 + 0.05 \times 4\} - 0.4^2 = 0.64.$$

截断降低了方差, 却引入 -0.2 的偏差; 两者必须同时报告。

再看一组恰好含 16 个 a 、3 个 b 和 1 个 c 的二十粒子样本。原始权重总和为 20, 归一化后的三点质量恰为 $(0.4, 0.3, 0.3)$ 。按这些质量做 20 次多项重采样, 三点后代数的条件期望为 $(8, 6, 6)$; 重采样后无权平均的条件期望仍为 0.6, 但条件方差增加了

$$\frac{0.6(1-0.6)}{20} = 0.012.$$

若先截断, 归一化质量变成 $(0.5, 0.375, 0.125)$, 重采样均值的条件期望是 0.5, 不会恢复被截断改变的目标。原始和截断权重在这组粒子上的经验有效样本量分别约为 $400/52 = 7.69$ 与 $256/20 = 12.8$: 较均匀的权重提高了这一诊断量, 但不证明偏差消失。

经验有效样本量常写成

$$\hat{n}_{\text{eff}} = \frac{(\sum_i \tilde{w}_i)^2}{\sum_i \tilde{w}_i^2}.$$

它是权重退化的诊断量, 不是对所有估计目标都成立的精确独立样本数。截断权重可降低方差, 却通常引入偏差; 重采样减少后续计算中的权重不均, 却增加额外随机性。本节的“自归一化”是随机比值估计, 第 9.3 节的自归一化集中则用随机设计矩阵度量累计噪声, 二者对象不同。

8.10 指数矩与集中不等式

8.10.1 Chernoff 方法把尾事件变成指数矩

对任意 $\lambda > 0$, 函数 $x \mapsto e^{\lambda x}$ 单调。Markov 不等式给出

$$\mathbb{P}(X \geq t) = \mathbb{P}(e^{\lambda X} \geq e^{\lambda t}) \leq e^{-\lambda t} \mathbb{E}[e^{\lambda X}]. \quad (8.23)$$

随后对 λ 优化, 便得到 Chernoff 方法。整个方法依赖相应指数矩有限; 若 $\mathbb{E}e^{\lambda X} = \infty$, 式 (8.23) 虽形式上仍真, 却不给出有用上界。

中心化随机变量 X 若满足

$$\mathbb{E}[e^{\lambda X}] \leq \exp\left(\frac{\lambda^2 \sigma^2}{2}\right), \quad \lambda \in \mathbb{R},$$

就称它为参数 σ^2 的**次高斯变量** (sub-Gaussian random variable)。代入 Chernoff 界并取 $\lambda = t/\sigma^2$, 得到

$$\mathbb{P}(X \geq t) \leq \exp\left(-\frac{t^2}{2\sigma^2}\right).$$

“次高斯”描述的是指数矩或尾部上界, 不表示变量本身服从高斯分布。

8.10.2 Hoeffding 界的完整推导

引理 8.12 Hoeffding 引理 若 $\mathbb{E}X = 0$ 且 $X \in [a, b]$ 几乎处处成立, 则

$$\mathbb{E}[e^{\lambda X}] \leq \exp\left\{\frac{\lambda^2(b-a)^2}{8}\right\}, \quad \lambda \in \mathbb{R}.$$

证明. 凸性说明, 对 $x \in [a, b]$, 指数函数位于连接端点的弦下方:

$$e^{\lambda x} \leq \frac{b-x}{b-a}e^{\lambda a} + \frac{x-a}{b-a}e^{\lambda b}.$$

取期望并使用 $\mathbb{E}X = 0$, 右侧成为一个只依赖 $\lambda(b-a)$ 与均值位置的二点分布矩母函数。令 $p = -a/(b-a)$, 对其对数作二阶导数, 可得二阶导数至多为 $1/4$; 该对数在 $\lambda = 0$ 处的函数值和一阶导数均为零。两次积分于是给出

$$\log \mathbb{E}[e^{\lambda X}] \leq \frac{\lambda^2(b-a)^2}{8}.$$

指数化即得结论。 ■

定理 8.13 Hoeffding 不等式 设 $X_1, \dots, X_n$ 相互独立, 且 $X_i \in [a_i, b_i]$ 几乎处处成立。则对 $t > 0$,

$$\mathbb{P}\left(\sum_{i=1}^n (X_i - \mathbb{E}X_i) \geq t\right) \leq \exp\left\{-\frac{2t^2}{\sum_{i=1}^n (b_i - a_i)^2}\right\}.$$

证明. 记 $S = \sum_i (X_i - \mathbb{E}X_i)$ 。对 $\lambda > 0$, 独立性使指数矩分解:

$$\begin{aligned}\mathbb{P}(S \geq t) &\leq e^{-\lambda t} \mathbb{E}[e^{\lambda S}] \\ &= e^{-\lambda t} \prod_{i=1}^n \mathbb{E}[e^{\lambda(X_i - \mathbb{E}X_i)}] \\ &\leq \exp\left\{-\lambda t + \frac{\lambda^2}{8} \sum_{i=1}^n (b_i - a_i)^2\right\}.\end{aligned}$$

右侧关于 λ 的最小点为

$$\lambda^* = \frac{4t}{\sum_i (b_i - a_i)^2}.$$

代回即得结论。对 $-S$ 使用同一结果, 再用联合界可得双侧版本。 ■

若 $X_i \in [0, 1]$ 独立, 则样本平均满足

$$\mathbb{P}(|\bar{X}_n - \mathbb{E}\bar{X}_n| \geq \varepsilon) \leq 2e^{-2n\varepsilon^2}.$$

有界性进入 Hoeffding 引理, 独立性进入矩母函数乘积; 删除任一条件都不能沿用这份证明。

8.10.3 Bernstein 界利用方差信息

若独立中心化变量满足 $|X_i| \leq M$, 并记 $v = \sum_i \mathbb{E}[X_i^2]$, 则 Bernstein 不等式的一个版本为

$$\mathbb{P}\left(\sum_{i=1}^n X_i \geq t\right) \leq \exp\left\{-\frac{t^2}{2(v + Mt/3)}\right\}. \quad (8.24)$$

为看清两个尺度的来源, 取 $0 < \lambda < 3/M$ 。由指数级数及 $|X_i|^k \leq M^{k-2}X_i^2$ ($k \geq 2$), 有

$$\mathbb{E}e^{\lambda X_i} \leq 1 + \frac{\lambda^2 \mathbb{E}X_i^2}{2(1 - \lambda M/3)} \leq \exp\left\{\frac{\lambda^2 \mathbb{E}X_i^2}{2(1 - \lambda M/3)}\right\}.$$

这里第一阶项因中心化而消失, 常数 $1/3$ 来自用几何级数控制

$$\sum_{k \geq 3} \frac{(\lambda M)^{k-2}}{k!}.$$

独立性使各指数矩相乘, Chernoff 步骤于是给出

$$\mathbb{P}\left(\sum_i X_i \geq t\right) \leq \exp\left\{-\lambda t + \frac{\lambda^2 v}{2(1 - \lambda M/3)}\right\}.$$

取 $\lambda = t/(v + Mt/3)$ 便得到式 (8.24)。小偏差区域由 v 主导，呈高斯型；大偏差区域由 Mt 主导，呈指数型。

例如 $B_i \sim \text{Bernoulli}(0.01)$ 独立，考虑 $\bar{B}_n - 0.01 \geq 0.05$ 。Hoeffding 上界为 $\exp(-0.005n)$ ，而 Bernstein 上界约为

$$\exp\left\{-\frac{0.05^2 n}{2(0.01 \times 0.99 + 0.05/3)}\right\} \approx \exp(-0.047n).$$

低发生率使实际方差远小于区间最坏尺度，所以后者明显更紧；当方差接近区间允许的最大值或偏差进入线性尺度时，Bernstein 并不保证处处优于 Hoeffding。

对重尾变量，方差可能不存在，指数矩也可能对所有正参数发散。此时 Chebyshev、Hoeffding 和 Bernstein 各自在矩、范围或指数矩步骤失效。可以增加截断、稳健均值或仅用有限 p 阶矩推导多项式尾界，但所得估计对象和偏差需要重新说明，不能继续声称高斯型集中。

8.11 多个对象与随机函数的联合误差

8.11.1 选择候选需要同时成立的保证

设有限候选类 $\mathcal{H} = \{h_1, \dots, h_M\}$ ，损失 $\ell(h, Z) \in [0, 1]$ 。真实风险与经验风险分别为

$$R(h) = \mathbb{E}[\ell(h, Z)], \quad \hat{R}_n(h) = \frac{1}{n} \sum_{i=1}^n \ell(h, Z_i),$$

其中 $Z_1, \dots, Z_n$ 独立同分布。对预先固定的单个 h ，Hoeffding 不等式给出

$$\mathbb{P}(|\hat{R}_n(h) - R(h)| > \varepsilon) \leq 2e^{-2n\varepsilon^2}.$$

但经验最优候选 $\hat{h} \in \arg \min_h \hat{R}_n(h)$ 由同一批数据选出，不是预先固定对象。只控制一个候选不能排除“恰好因噪声看起来最好”的选择偏差。

定理 8.14 有限函数类的一致误差界 在上述条件下，对任意 $\delta \in (0, 1)$ ，以至少 $1 - \delta$ 的概率同时对所有 $h \in \mathcal{H}$ 有

$$|\hat{R}_n(h) - R(h)| \leq \sqrt{\frac{\log(2M/\delta)}{2n}}. \quad (8.25)$$

证明. 对每个 h 定义坏事件

$$A_h = \{|\hat{R}_n(h) - R(h)| > \varepsilon\}.$$

单函数 Hoeffding 界给出 $\mathbb{P}(A_h) \leq 2e^{-2n\epsilon^2}$ 。由联合界,

$$\mathbb{P}\left(\bigcup_{h \in \mathcal{H}} A_h\right) \leq 2Me^{-2n\epsilon^2}.$$

令右侧等于 δ , 解得 $\epsilon = \sqrt{\log(2M/\delta)/(2n)}$ 。在坏事件并集的补集上, 结论对全部候选同时成立。 ■

令 $h^* \in \arg \min_h R(h)$, 并在式(8.25)成立的事件上记右侧为 ϵ_n 。则

$$\begin{aligned} R(\hat{h}) &\leq \hat{R}_n(\hat{h}) + \epsilon_n \\ &\leq \hat{R}_n(h^*) + \epsilon_n \\ &\leq R(h^*) + 2\epsilon_n. \end{aligned}$$

第二步正是经验最优性的用途。候选数只通过 $\log M$ 进入, 但若候选类本身由同一数据任意生成, 简单地把最终数量代入 M 未必合法; 需要把生成过程纳入统一控制对象。例如 $M = 100$ 、 $n = 1000$ 、 $\delta = 0.05$ 时, 式(8.25)右侧约为

$$\sqrt{\frac{\log 4000}{2000}} \approx 0.0644.$$

这个数同时控制一百个预先固定候选, 而不是给每个候选各自提供 95% 保证; 后一做法的联合失败概率可能远大于 5%。

8.11.2 取值模式、覆盖与随机投影

无限函数类不能直接按元素做联合界。第4章建立的取值模式与覆盖数提供两种有限化方法: 若样本上只有有限种损失向量, 只需对这些模式联合控制; 若每个函数都能由有限 ϵ -网中的代表逼近, 则先控制网点, 再用 Lipschitz 性质把误差转回原函数。这里的关键不是形式上把“无限”改写成一个大数字, 而是证明离散代表确实控制所需误差度量。

引理 8.15 覆盖数的有限网控制 设 $(\mathcal{F}, d)$ 具有有限 ϵ -网 $\mathcal{N}_\epsilon$, 其大小为 $N(\mathcal{F}, d, \epsilon)$ 。若随机过程 $\{Z_f : f \in \mathcal{F}\}$ 满足

$$|Z_f - Z_g| \leq Ld(f, g)$$

几乎处处对所有 f, g 成立, 并且相关上确界可测, 则对任意 $t > 0$,

$$\mathbb{P}\left\{\sup_{f \in \mathcal{F}} |Z_f| > t + L\epsilon\right\} \leq N(\mathcal{F}, d, \epsilon) \sup_{f \in \mathcal{F}} \mathbb{P}(|Z_f| > t). \quad (8.26)$$

证明. 对每个 f 选取满足 $d(f, g_f) \leq \varepsilon$ 的 $g_f \in \mathcal{N}_\varepsilon$ 。则

$$|Z_f| \leq |Z_{g_f}| + L\varepsilon,$$

所以左侧坏事件包含在 $\bigcup_{g \in \mathcal{N}_\varepsilon} \{|Z_g| > t\}$ 中。对这个有限并集使用联合界即得结论。 ■

若 $Z_f = \hat{R}_n(f) - R(f)$, 且经验风险与真实风险各自关于 d 都是 L_0 -Lipschitz, 则引理中的过程常数是 $2L_0$ 。因此, 网格大小、离散误差 $2L_0\varepsilon$ 和单点尾界必须一起进入结论; 只报告覆盖数而不验证 Lipschitz 传递还不能控制原函数类。

下面的随机投影会把范数失真化成高斯平方和。若 $G_1, \dots, G_k$ 相互独立且都服从标准高斯分布 $\mathcal{N}(0, 1)$, 则称

$$Z = \sum_{j=1}^k G_j^2$$

服从自由度为 k 的**卡方分布** (chi-square distribution), 记为 $Z \sim \chi_k^2$ 。这个定义也给出后文调用尾界的接口: 只要证明一个随机二次量能写成 k 个独立标准高斯的平方和, 就可以直接使用下面的结论。

引理 8.16 χ^2 变量的尾界 若 $Z \sim \chi_k^2$, 其中 k 为正整数, 则对每个 $x > 0$,

$$\mathbb{P}\{Z - k \geq 2\sqrt{kx} + 2x\} \leq e^{-x}, \quad \mathbb{P}\{k - Z \geq 2\sqrt{kx}\} \leq e^{-x}.$$

因而对 $0 < \varepsilon < 1$,

$$\mathbb{P}\left(\left|\frac{Z}{k} - 1\right| > \varepsilon\right) \leq 2 \exp\left(-\frac{k\varepsilon^2}{8}\right). \quad (8.27)$$

随机投影给出一个有限集合的直接算例。设固定点集 $\{\mathbf{x}_1, \dots, \mathbf{x}_N\} \subset \mathbb{R}^d$, 随机矩阵 $\mathbf{A} \in \mathbb{R}^{k \times d}$ 的元素独立服从 $\mathcal{N}(0, 1/k)$ 。对预先固定且非零、因而不依赖 $\mathbf{A}$ 的向量 $\mathbf{v}$, 有

$$\frac{k\|\mathbf{A}\mathbf{v}\|_2^2}{\|\mathbf{v}\|_2^2} \sim \chi_k^2.$$

所以仅在 $0 < \varepsilon < 1$ 的相对误差范围内, 式 (8.27) 直接给出

$$\mathbb{P}\left(\left|\|\mathbf{A}\mathbf{v}\|_2^2 - \|\mathbf{v}\|_2^2\right| > \varepsilon\|\mathbf{v}\|_2^2\right) \leq 2 \exp\left(-\frac{k\varepsilon^2}{8}\right).$$

对 $N \geq 2$ 、 $\delta \in (0, 1)$, 把 $\mathbf{v}$ 依次取为至多 $N(N-1)/2$ 个预先固定的点对

差，并用联合界，可知例如取

$$k \geq \frac{8}{\varepsilon^2} \log \frac{N(N-1)}{\delta}$$

时，所有点对距离以至少 $1 - \delta$ 的概率同时近似保持。固定单个方向的尾界之所以能支持后续任意点对查询，正是因为有限集合已被同时控制。

8.11.3 有界差控制数据函数

有些目标不是单个样本平均，而是整个数据集的函数 $F(Z_1, \dots, Z_n)$ 。若替换第 i 个输入最多改变 c_i ，即

$$\sup_{z, z'_i} |F(z_1, \dots, z_i, \dots, z_n) - F(z_1, \dots, z'_i, \dots, z_n)| \leq c_i,$$

则独立输入下的 McDiarmid 不等式给出

$$\mathbb{P}(F - \mathbb{E}F \geq t) \leq \exp \left\{ -\frac{2t^2}{\sum_{i=1}^n c_i^2} \right\}. \quad (8.28)$$

其证明把 F 依次对前 i 个观测条件化，形成 Doob 鞅；每步有界差控制一个鞅增量，再使用 Hoeffding 型指数矩界。独立性保证逐步揭示观测时的条件结构，有界差则限制单个观测的影响。

8.11.4 对称化把未知期望换成样本差

设 $\mathcal{F}$ 是一族取值于 $[-1, 1]$ 的函数，定义

$$\Delta(\mathbf{Z}) = \sup_{f \in \mathcal{F}} \left| \mathbb{E}f(\mathbf{Z}) - \frac{1}{n} \sum_{i=1}^n f(Z_i) \right|.$$

引入独立同分布副本 $Z'_1, \dots, Z'_n$ 。Jensen 不等式给出

$$\mathbb{E}_{\mathbf{Z}} \Delta(\mathbf{Z}) \leq \mathbb{E}_{\mathbf{Z}, \mathbf{Z}'} \sup_{f \in \mathcal{F}} \left| \frac{1}{n} \sum_{i=1}^n (f(Z'_i) - f(Z_i)) \right|.$$

由于每对 (Z_i, Z'_i) 交换后联合分布不变，引入独立 Rademacher 符号 $\sigma_i \in \{-1, 1\}$ 不会改变差的联合分布。因此

$$\mathbb{E} \Delta(\mathbf{Z}) \leq 2 \mathbb{E}_{\mathbf{Z}, \boldsymbol{\sigma}} \sup_{f \in \mathcal{F}} \left| \frac{1}{n} \sum_{i=1}^n \sigma_i f(Z_i) \right|.$$

右侧是经验 Rademacher 复杂度的两倍。它只在观测点上考察函数类与随机符号对齐的能力，把未知总体期望转成了条件于样本的随机和。

若 $\phi_i : \mathbb{R} \rightarrow \mathbb{R}$ 均为 L -Lipschitz 且 $\phi_i(0) = 0$ ，则对任意不必关于取负封

闭的函数类 $\mathcal{F}$ ，带绝对值的收缩不等式为

$$\mathbb{E}_{\sigma} \sup_{f \in \mathcal{F}} \left| \sum_i \sigma_i \phi_i(f(Z_i)) \right| \leq 2L \mathbb{E}_{\sigma} \sup_{f \in \mathcal{F}} \left| \sum_i \sigma_i f(Z_i) \right|.$$

一般情形需要先在取值向量类中临时加入零向量，再分别控制随机和的两个方向；这一步产生因子 2。若变换后的取值向量类关于取负封闭，例如 $\mathcal{F} = -\mathcal{F}$ 且每个 ϕ_i 都是奇函数，则可去掉该因子。这个不等式允许把预测函数的复杂度传到 Lipschitz 损失。若损失不全局 Lipschitz 或相关上确界不可积，必须限制作用范围或使用其他矩条件。

标量收缩可用逐坐标替换证明。先设函数类在固定样本上的取值向量组成有限集 $\mathcal{A} \subset \mathbb{R}^n$ ，并只考虑不带绝对值的上确界。固定前 $n-1$ 个符号，把相应部分记为 $U_{\mathbf{a}}$ 。条件于这些符号，左侧最后一个坐标的贡献为

$$\frac{1}{2} \sup_{\mathbf{a}} \{U_{\mathbf{a}} + \phi_n(a_n)\} + \frac{1}{2} \sup_{\mathbf{a}} \{U_{\mathbf{a}} - \phi_n(a_n)\}.$$

取两个上确界的近似最大元 $\mathbf{a}, \mathbf{b}$ ，并使用 $\phi_n(a_n) - \phi_n(b_n) \leq L|a_n - b_n|$ 。按 $a_n - b_n$ 的符号选择正负方向，便得到上式不超过

$$\frac{1}{2} \sup_{\mathbf{a}} \{U_{\mathbf{a}} + La_n\} + \frac{1}{2} \sup_{\mathbf{a}} \{U_{\mathbf{a}} - La_n\}.$$

从最后一个坐标向前迭代，即得到单侧收缩。对随机和的正、负两个方向分别应用该结论，再用 $\sup |S| = \max\{\sup S, \sup(-S)\}$ 时，还需要保证两个单侧上确界非负。具体地，令 $\mathcal{A}_0 = \mathcal{A} \cup \{\mathbf{0}\}$ 。由于 $\phi_i(0) = 0$ ，对每组固定符号都有

$$\sup_{\mathbf{a} \in \mathcal{A}} \left| \sum_i \sigma_i \phi_i(a_i) \right| \leq \sup_{\mathbf{a} \in \mathcal{A}_0} \sum_i \sigma_i \phi_i(a_i) + \sup_{\mathbf{a} \in \mathcal{A}_0} \left(- \sum_i \sigma_i \phi_i(a_i) \right).$$

两个单侧上确界因包含零向量而非负。分别对 σ 与 $-\sigma$ 应用单侧收缩，再利用二者同分布，得到

$$\mathbb{E}_{\sigma} \sup_{\mathbf{a} \in \mathcal{A}} \left| \sum_i \sigma_i \phi_i(a_i) \right| \leq 2L \mathbb{E}_{\sigma} \sup_{\mathbf{a} \in \mathcal{A}_0} \sum_i \sigma_i a_i \leq 2L \mathbb{E}_{\sigma} \sup_{\mathbf{a} \in \mathcal{A}} \left| \sum_i \sigma_i a_i \right|.$$

这就闭合了带绝对值版本的证明。一般函数类可由有限子类逼近并使用单调极限；不可数类还须保留前述可测性条件。

线性函数类展示了这一复杂度怎样落到熟悉的范数上。设

$$\mathcal{F} = \{\mathbf{z} \mapsto \langle \mathbf{w}, \mathbf{z} \rangle : \|\mathbf{w}\|_2 \leq B\}, \quad \|\mathbf{Z}_i\|_2 \leq R.$$

由对偶范数和 Jensen 不等式,

$$\begin{aligned}\hat{\mathfrak{R}}_{\mathcal{Z}}^{\text{abs}}(\mathcal{F}) &= \frac{B}{n} \mathbb{E}_{\sigma} \left\| \sum_{i=1}^n \sigma_i \mathbf{Z}_i \right\|_2 \\ &\leq \frac{B}{n} \left(\sum_{i=1}^n \|\mathbf{Z}_i\|_2^2 \right)^{1/2} \leq \frac{BR}{\sqrt{n}}.\end{aligned}$$

参数范数、样本范数和样本量分别进入 B 、 R 与 $n^{-1/2}$ 。机器学习理论部分会在具体损失和模型类上继续把这一期望复杂度转换为高概率泛化界。

把 Rademacher 符号替换为独立标准高斯变量 g_i , 得到高斯复杂度

$$\mathbb{E}_{\mathbf{g}} \sup_{f \in \mathcal{F}} \left| \frac{1}{n} \sum_i g_i f(\mathbf{Z}_i) \right|.$$

记上述带绝对值的经验 Rademacher 复杂度和高斯复杂度分别为 $\hat{\mathfrak{R}}_{\mathcal{Z}}^{\text{abs}}(\mathcal{F})$ 与 $\hat{\mathfrak{G}}_{\mathcal{Z}}^{\text{abs}}(\mathcal{F})$ 。对任意固定样本, 只要这些上确界可测且期望有限, 就有单向比较

$$\hat{\mathfrak{R}}_{\mathcal{Z}}^{\text{abs}}(\mathcal{F}) \leq \sqrt{\frac{\pi}{2}} \hat{\mathfrak{G}}_{\mathcal{Z}}^{\text{abs}}(\mathcal{F}).$$

反方向一般不能只付出普适常数; 不附加几何条件时, 一个通用界会带 $O(\sqrt{\log(en)})$ 因子。函数类在样本上的取值向量若恰为坐标向量及其相反数, 高斯复杂度与 Rademacher 复杂度之比就达到 $\Theta(\sqrt{\log n})$ 。因此, 在泛化界中用一种复杂度替换另一种时, 必须保留比较方向及相应因子; 高斯过程的协方差度量和覆盖数结构仍需单独估计。

8.12 可交换性与有限样本秩

8.12.1 可交换性保留重排对称

随机变量 $Z_1, \dots, Z_m$ 若对每个排列 π 都有

$$(Z_1, \dots, Z_m) \stackrel{d}{=} (Z_{\pi(1)}, \dots, Z_{\pi(m)}),$$

就称它们**可交换** (exchangeable)。独立同分布蕴含可交换, 但反向不成立。例如先抽取随机概率 Θ , 再条件于 Θ 独立生成 Bernoulli 观测; 边缘上这些观测可交换, 却因共享 Θ 而相关。

可交换性不提供样本平均的独立乘积结构, 因而不能直接代入 Hoeffding 证明。它提供的是标签位置的对称性: 若对全部观测使用同一规则计算分数, 则每个分数占据任一秩的位置具有相同机会。共形预测利用的正是这项有限样本对称性。

8.12.2 秩的对称性

设实值分数 $S_1, \dots, S_{m+1}$ 可交换, 并暂假它们几乎必然没有并列值。令

$$R_{m+1} = 1 + \sum_{i=1}^m \mathbb{I}\{S_i < S_{m+1}\}$$

为最后一个分数从小到大的秩。由于交换任意两个坐标不改变联合分布, 而无并列值时每个样本恰占一个秩, 所以

$$\mathbb{P}(R_{m+1} = r) = \frac{1}{m+1}, \quad r = 1, \dots, m+1. \quad (8.29)$$

这是一项精确的有限样本结论, 不依赖中心极限定理。

若存在并列值, 使用“严格小于”的秩不再均匀。可以为每个分数附加独立连续随机数并按字典序打破并列, 此时恢复精确均匀秩; 也可以采用保守的不随机化分位数, 得到覆盖率至少为目标值, 但通常不再精确等于目标值。

8.12.3 拆分共形预测的基本覆盖证明

设训练数据用于拟合一个固定预测规则, 随后有 m 个校准样本和一个未来样本。条件于训练数据, 假设校准样本与未来样本可交换。用同一个不一致性函数计算

$$S_i = s(X_i, Y_i), \quad i = 1, \dots, m+1.$$

分数越大表示候选标签与预测规则越不相容。给定错误率 $\alpha \in (0, 1)$, 令

$$k = \lceil (m+1)(1-\alpha) \rceil.$$

若 $k \leq m$, 令 q 为前 m 个校准分数的第 k 小值; 若 $k = m+1$, 约定 $q = +\infty$ 。对新输入 X_{m+1} , 定义预测集合

$$C(X_{m+1}) = \{y : s(X_{m+1}, y) \leq q\}. \quad (8.30)$$

例如 $m = 9$ 、 $\alpha = 0.2$ 时, $k = \lceil 10 \times 0.8 \rceil = 8$ 。若排序后的校准分数为 $0.1, 0.2, \dots, 0.9$, 则 $q = 0.8$: 候选标签的分数为 0.75 时纳入集合, 为 0.85 时排除。若仍只有九个校准样本却要求 $\alpha = 0.05$, 则 $k = \lceil 9.5 \rceil = 10 = m+1$, 按约定得到 $q = +\infty$ 。这不是计算故障, 而是有限样本不足以用非随机秩给出如此高的非平凡覆盖水平。

定理 8.17 拆分共形的有限样本覆盖 在上述条件下,

$$\mathbb{P}(Y_{m+1} \in C(X_{m+1})) \geq 1 - \alpha.$$

证明. 先假设分数无并列值。若未来真实标签未被覆盖, 则 $S_{m+1} > q$, 所以未来分数在全部 $m+1$ 个分数中的秩严格大于 k 。由式 (8.29),

$$\mathbb{P}(S_{m+1} > q) = \mathbb{P}(R_{m+1} > k) = \frac{m+1-k}{m+1} \leq \alpha.$$

取补事件即得覆盖结论。

若有并列值, 采用集合定义中的 “ $\leq q$ ” 会把边界并列分数纳入预测集合。相较于随机打破并列后的精确秩, 这只会增加覆盖事件, 因此同一不等式仍成立。若希望得到更接近精确的覆盖率, 可显式随机化边界并列项, 但必须把该随机化纳入算法与概率空间。 ■

这里的概率保证是**边际覆盖**: 条件于训练数据后, 它仍对随机的校准样本和未来样本共同取平均; 若采用随机并列处理, 还包括该随机性。解除对训练数据的条件后, 总体覆盖率仍至少为 $1 - \alpha$ 。但这个结论一般不推出对每个固定输入 x 都有

$$\mathbb{P}(Y_{m+1} \in C(X_{m+1}) \mid X_{m+1} = x) \geq 1 - \alpha,$$

也不自动保证每个群组内都达到同一覆盖率。逐输入、逐群组或时间条件覆盖需要额外结构、假设或专门的校准方法, 不能仅由可交换秩推出。

证明依赖两处对称性。训练与校准拆分使评分规则在校准阶段保持固定; 校准样本与未来样本可交换, 使未来分数的秩没有特殊位置。若反复查看校准误差后修改模型或分数函数, 评分规则已依赖校准标签, 条件可交换性可能被破坏。时间序列中的未来点通常也不能与过去点任意重排; 自适应收集会让被选中的样本位置携带额外信息。此时失效的是均匀秩步骤, 而不是把分位数索引稍作调整就能修复。第二卷“基础、理论和可信性”的“可靠性的保证”节建立具体预测范围后, 将回用这一秩保证。

8.13 本章小结

概率空间把不确定结果组织为事件测度, 随机变量再把结果映射成可积分的数值。Radon-Nikodym 导数回答怎样在兼容零集的前提下改变参考分布; 条件期望则回答可用信息增加后, 怎样保留每个可识别事件上的平均。前者改变积分所用的测度, 后者改变答案允许依赖的 σ 代数, 二者不能混为同一种“加权”。

对带噪观测，期望给出目标，大数定律说明样本平均何时稳定，中心极限定理描述缩放后的渐近波动，集中不等式则直接控制固定样本下的尾部概率。蒙特卡洛、重要性采样、控制变量和 Rao-Blackwell 化都估计同一个积分，却分别通过改变采样分布、加入已知平均和消去条件噪声来改变方差；无偏、一致与有限方差需要分别核对。

从有限候选中按数据选择对象时，固定单个候选的误差界不够。联合界给出有限类的同时保证，对称化与随机复杂度把这一思路扩展到结构化无限类。可交换秩则提供另一条有限样本路线：它不依赖独立平均，而依赖重排对称。渐近近似、固定样本尾界、函数类同时误差和秩覆盖支持的是不同陈述。下一章将研究观测相关、按过去信息自适应选择以及长期迭代时，这些条件需要怎样改变。

随机过程与随机逼近

第8章考察独立观测的平均。若每次观测都来自同一个分布，大数定律说明样本均值是否接近期望，集中不等式进一步控制有限样本误差。然而，许多学习过程会把当前结果带到下一步：采样器从当前位置产生新状态，算法根据已有数据选择下一次查询，参数又用刚得到的噪声观测继续更新。此时，记录数仍在增加，独立性却已经消失。

本章围绕一个均值求根问题研究这种时间结构。设长期观测均值为 μ ，目标是求方程

$$h(\theta) = \mathbb{E}[Y - \theta] = \mu - \theta = 0 \quad (9.1)$$

的根 $\theta^* = \mu$ 。若观测 Y_t 来自 Markov 链，它们可能彼此相关，因而不能预设独立性；若下一次观测方向由过去结果决定，误差还会与设计共同演化；若不保存全部数据而直接更新 $\theta^{(t)}$ ，问题又从估计固定平均变成带噪迭代。本章以均值求根作为贯穿示例，但各节并不估计同一个参数：具体目标会从长期均值扩展到线性参数和一般平均漂移的根。四种视角共享的是如何在时间依赖或自适应信息下分离平均信号与噪声，其中鞅提供连接这些任务的条件噪声工具。

我们先判断相关序列的时间平均何时仍指向 μ ，再用鞅刻画给定过去后无法预测的噪声。条件方差给出比统一增量界更细的序贯控制，带可预测特征的向量鞅则把误差放进随数据增长的设计矩阵。最后，随机逼近把这些噪声工具接到求根更新，并说明步长、平均漂移与迭代有界性各自承担什么作用。贯穿各节的重点不是把“独立样本数”换成“时间步数”，而是辨认过去信息怎样改变当前分布，以及证明中哪一步仍能利用条件平均为零。

9.1 Markov 链与长期平均

9.1.1 转移规则、平稳分布与时间齐次性

设 $(Z_t)_{t \geq 0}$ 取值于可测空间 $(\mathcal{Z}, \mathcal{A})$ 。若对每个 $B \in \mathcal{A}$,

$$\mathbb{P}(Z_{t+1} \in B \mid Z_0, \dots, Z_t) = \mathbb{P}(Z_{t+1} \in B \mid Z_t),$$

则称 (Z_t) 为 **Markov 链** (Markov chain)。这个条件不是说过去没有影响, 而是说当前状态已经保存了预测下一步所需的全部历史信息。若右侧可统一写成 $P(Z_t, B)$, 且转移核 P 不随 t 改变, 则链是**时间齐次的** (time-homogeneous)。时间齐次描述机制不变, 不代表 Z_t 的边缘分布不随时间改变¹。

这里的转移核需要同时满足两项可测性条件: 固定 z 时, $P(z, \cdot)$ 是 $(\mathcal{Z}, \mathcal{A})$ 上的概率测度; 固定 $B \in \mathcal{A}$ 时, $P(\cdot, B)$ 是可测函数。对有界可测函数 f , 记

$$Pf(z) = \int_{\mathcal{Z}} f(z') P(z, dz').$$

两个核的复合按

$$(PQ)(z, B) = \int_{\mathcal{Z}} Q(z', B) P(z, dz')$$

定义; 它表示先按 P 走一步, 再按 Q 走一步。令 $P^0(z, B) = \mathbb{I}\{z \in B\}$, $P^{m+1} = P^m P$, 则时间齐次链满足

$$\mathbb{P}(Z_{t+m} \in B \mid Z_t = z) = P^m(z, B), \quad P^{m+n}(z, B) = \int_{\mathcal{Z}} P^n(z', B) P^m(z, dz'). \quad (9.2)$$

第二个等式称为**Chapman-Kolmogorov 关系**。证明可直接使用条件概率的塔式性质: 给定 $Z_{t+m} = z'$ 后, Markov 性质把后 n 步的条件概率化为 $P^n(z', B)$; 再对 Z_{t+m} 在给定 $Z_t = z$ 时的分布 $P^m(z, dz')$ 积分, 就得到右侧。取 $n = 1$ 并归纳, 还同时证明了第一个等式及核幂确实给出多步转移。

概率分布 π 若满足

$$\pi(B) = \int_{\mathcal{Z}} P(z, B) \pi(dz), \quad B \in \mathcal{A}, \quad (9.3)$$

就称为 P 的**平稳分布** (stationary distribution)。若 $Z_0 \sim \pi$, 式 (9.3) 保证每个 Z_t 仍服从 π ; 若从指定状态 z_0 启动, 平稳性本身却没有说明 $\mathcal{L}(Z_t)$ 会趋向 π 。恒等转移核 $P(z, B) = \mathbb{I}\{z \in B\}$ 保持任意分布, 但它永远不忘记初态, 这已经表明“保持目标”和“到达目标”是两项不同要求。

“平稳分布”是核与一个概率分布之间的关系, **平稳过程** (stationary process) 则要求任意有限维联合分布在时间平移后不变。对时间齐次 Markov

¹ S. P. Meyn, R. L. Tweedie, *Markov Chains and Stochastic Stability*, Cambridge University Press, 2009, 2nd ed.

链, 若 $Z_0 \sim \pi$ 且 $\pi P = \pi$, 则

$$\mathbb{P}(Z_0 \in dz_0, \dots, Z_m \in dz_m) = \pi(dz_0) \prod_{j=1}^m P(z_{j-1}, dz_j).$$

把起点向后平移一格时, 先对 z_0 积分, $\pi P = \pi$ 把 Z_1 的边缘重新化为 π , 其余转移核不变; 反复应用便证明所有有限维分布都不随平移改变。因此, 从平稳分布启动的时间齐次链是平稳过程。只知道某一个时刻的边缘分布等于 π , 却没有核不变或联合分布条件时, 不能据此断言整个过程平稳。

一个常用的保持性条件是**细致平衡** (detailed balance)

$$\pi(dz)P(z, dz') = \pi(dz')P(z', dz). \quad (9.4)$$

它要求平稳运行时任意两处之间的概率流量正反相等。对 z 积分便得到 (9.3), 所以细致平衡足以推出平稳性。反向不成立: 围绕三个状态单向循环的链可以保持均匀分布, 却没有逐边对称的反向流。细致平衡是构造采样链的便利证书, 不是遍历平均成立的必要定义。

示例 9.1 相关的两状态观测 令 $Z_t \in \{0, 2\}$, 并把观测直接取为 $Y_t = Z_t$ 。转移矩阵按状态 0, 2 排序为

$$P = \begin{pmatrix} 0.9 & 0.1 \\ 0.2 & 0.8 \end{pmatrix}.$$

平稳分布为 $\pi = (2/3, 1/3)^\top$, 因为 $P^\top \pi = \pi$ 。长期均值因此是

$$\mu = \mathbb{E}_\pi[Y] = \frac{2}{3}.$$

两条跨状态概率流都等于 $(2/3) \times 0.1 = (1/3) \times 0.2 = 1/15$, 故该链还满足细致平衡。从状态 0 启动时, Y_0 不服从 π ; 转移规则时间齐次, 过程却要经过一段时间才接近平稳。

9.1.2 可达性、周期与收敛不是同一条件

在有限状态空间中, **不可约性** (irreducibility) 要求任意状态都能以正概率在有限步内到达任意另一状态。它排除多个互不连通的封闭类, 并保证平稳分布唯一。**周期** (period) 是从某状态返回自身的可能步数集合的最大公约数; 不可约链的所有状态具有相同周期。周期等于 1 时, 链称为**非周期的** (aperiodic)。

更具体地, 状态 i 到 j 可达, 是指存在 $m \geq 0$ 使 $P^m(i, \{j\}) > 0$ 。令 $T_i^+ = \inf\{t \geq 1 : Z_t = i\}$; 若 $\mathbb{P}_i(T_i^+ < \infty) = 1$, 就称 i 为**常返状态** (recurrent state)。有限链必有至少一个封闭常返类; 不可约性迫使全部状

态属于同一个类，所以每个状态都常返。从 i 出发，把从一次访问 i 起、到下一次返回 i 前为止的路径作为一个游程；返回时刻处的强 Markov 性说明这些游程独立同分布。记第 k 个游程的长度为 L_k 、其中访问 j 的次数为 R_k ，则大数定律给出

$$\frac{\sum_{k=1}^m R_k}{\sum_{k=1}^m L_k} \longrightarrow \frac{\mathbb{E}_i R_1}{\mathbb{E}_i L_1} = \pi_j \quad \text{几乎必然成立。}$$

长期时间占比来自多个游程的累计比值，而不是单次随机比值 R_k/L_k 。有限不可约性使返回时间均值有限；取 $j = i$ 时，每个游程恰计一次对 i 的访问，因而得到 $\pi_i = 1/\mathbb{E}_i T_i^+$ 。这个返回分解是遍历平均的概率证明入口。矩阵方面， $\mathbf{P}^\top$ 的特征值 1 对应唯一的概率右特征向量 $\boldsymbol{\pi}$ ；等价地， $\boldsymbol{\pi}^\top$ 是行随机转移矩阵 $\mathbf{P}$ 的唯一概率左特征向量。加入非周期性后，其他模态不会在单位圆上持续振荡，矩阵幂 $\mathbf{P}^t$ 才逐行趋于 $\boldsymbol{\pi}^\top$ 。这两条路线分别解释了为什么周期不妨碍时间占比，却会妨碍逐时刻分布收敛。

有限、不可约、非周期链满足

$$\mathbf{P}^t(\mathbf{z}, \cdot) \longrightarrow \boldsymbol{\pi}(\cdot) \quad \text{对每个初始状态 } \mathbf{z}, \quad (9.5)$$

其中有限状态下的收敛可以用**总变差距离**（total variation distance）衡量：对概率测度 ν, π ，定义

$$\|\nu - \pi\|_{\text{TV}} = \sup_{B \text{ 可测}} |\nu(B) - \pi(B)|.$$

不可约性与非周期性在这里服务于逐时刻分布收敛。时间平均的要求略有不同：有限不可约链即使有周期，对每个函数 $f: \mathcal{Z} \rightarrow \mathbb{R}$ 仍有

$$\frac{1}{n} \sum_{t=1}^n f(Z_t) \longrightarrow \mathbb{E}_\pi[f(Z)] \quad \text{几乎必然成立。} \quad (9.6)$$

例如在 0 与 2 之间确定性交替的链具有周期 2。从 0 出发时， Z_t 的分布在两个点之间来回切换，不存在逐步极限；但时间平均仍趋向 1。因此，讨论“遍历”时必须说明结论针对逐步分布、时间平均还是其他对象。

例 9.1 没有这些退化。其第二个特征值为 0.7。令 $\tilde{Y}_t = Y_t - \mu$ ，直接计算可得

$$\mathbb{E}[\tilde{Y}_{t+1} | Z_t] = 0.7\tilde{Y}_t. \quad (9.7)$$

反复使用塔式性质便得到 $\mathbb{E}[\tilde{Y}_{t+k} | Z_t] = 0.7^k \tilde{Y}_t$ 。若链从平稳分布启动，

$$\text{Corr}_\pi(Y_t, Y_{t+k}) = 0.7^k. \quad (9.8)$$

这个几何衰减同时展示了“收敛到平稳”和“样本之间仍相关”：边缘分布可以从一开始就等于 π ，相邻观测却不会因此独立。

9.1.3 混合速度、自相关与有效样本量

混合速度 (mixing rate) 描述链忘记初态的快慢。有限链常考察

$$d(t) = \sup_{z \in \mathcal{Z}} \|P^t(z, \cdot) - \pi\|_{TV},$$

并把使 $d(t) \leq \varepsilon$ 的最小 t 称为相应精度下的混合时间。这个最坏初态指标针对分布距离；估计某个特定 f 的时间平均时，还要考察 $f(Z_t)$ 自身的自相关。

若链平稳，记 $\sigma_f^2 = \text{Var}_\pi(f(Z_0))$, $\rho_f(k) = \text{Corr}_\pi(f(Z_0), f(Z_k))$ 。展开样本均值方差得到

$$\text{Var}\left(\frac{1}{n} \sum_{t=1}^n f(Z_t)\right) = \frac{\sigma_f^2}{n} \left[1 + 2 \sum_{k=1}^{n-1} \left(1 - \frac{k}{n}\right) \rho_f(k) \right]. \quad (9.9)$$

若 $\sum_{k \geq 1} |\rho_f(k)| < \infty$ ，括号中的量趋向

$$\tau_f = 1 + 2 \sum_{k=1}^{\infty} \rho_f(k),$$

称为积分自相关时间。用 $n_{\text{eff}} \approx n/\tau_f$ 表达 **自相关有效样本量** (autocorrelation effective sample size)，只是把该函数均值的渐近方差换算成独立样本尺度。它依赖 f ，也不同于重要性权重的有效样本量。

对例 9.1，式 (9.8) 给出

$$\tau_Y = 1 + 2 \sum_{k=1}^{\infty} 0.7^k = \frac{1 + 0.7}{1 - 0.7} = \frac{17}{3}.$$

因而长链对均值 μ 提供的信息量约为 $3n/17$ 个独立观测，而不是 n 个。若自相关为负， τ_f 也可能小于 1；有效样本量是特定估计量的方差等价口径，不是链中“真正保留下来”的样本条数。

9.1.4 一般状态空间需要返回条件

有限链可用矩阵、路径和周期描述可达性。连续或一般状态空间中，单点通常概率为零，“每个状态互相到达”不再是合适表述。固定 $(\mathcal{Z}, \mathcal{A})$ 上的非零参考测度 φ 。常用的 φ 不可约性要求：对每个满足 $\varphi(B) > 0$ 的 $B \in \mathcal{A}$ 以及每个初态 $z \in \mathcal{Z}$ ，链从 z 出发都有正概率在有限时间内到达 B ；若只研究某个不可约类，就先把 $\mathcal{Z}$ 限制为该类。在此基础上，**Harris 常返性** (Harris recurrence) 要求这些正测度集合以概率 1 被反复访问；**正 Harris 常返性** (positive Harris recurrence) 再要求存在不变概率分布。对 π 可积的 f ，正 Harris 常返性提供一般状态空间遍历大数定律的标准入口。

这里“反复访问”带有概率 1 的量词：从 $\mathcal{Z}$ 中的任意初态出发，每个满足 $\varphi(B) > 0$ 的集合 B 都几乎必然被访问无穷多次。仅有“以正概率最终到达”还不够，因为过程仍可能以正概率逃离后永不返回。正 Harris 常返链对其唯一不变概率 π 满足式 (9.6) 的一般状态空间版本，但函数必须 π 可积；若只知道局部可积或某个初态下样本值有限，不能推出该时间平均结论。

几何遍历性 (geometric ergodicity) 进一步要求到平稳分布的距离以几何速度下降，例如存在 $0 < r < 1$ 和依赖初态的有限 $C(z)$ ，使

$$\|P^t(z, \cdot) - \pi\|_{TV} \leq C(z)r^t.$$

它比“存在平稳分布”或“时间平均收敛”更强，常与额外矩条件一起用于中心极限定理、Poisson 方程和随机逼近中的相关噪声控制。几何遍历是方便而有力的充分条件，不是所有遍历链都必须满足的定义。

这些条件也解释了相关平均的边界。链若可约，长期平均可能由初始封闭类决定；链若只保持 π 而不能充分移动，有限预算误差可能很大；观测函数若不可积，平稳分布存在也不能定义所求均值。式 (9.1) 在 Markov 观测下仍有意义，需要的是链的长期平均确实识别 μ ，而不是把相关的 Y_t 假装成独立样本。

9.2 简单鞅、停时与序贯集中

9.2.1 滤过与不可预测增量

Markov 链保留了当前状态对未来的预测作用。另一种更适合分析累计噪声的结构，是只要求每个新增误差在给定过去后均值为零。在概率空间 $(\Omega, \mathcal{F}, \mathbb{P})$ 上，令每个 $\mathcal{F}_t$ 都是 $\mathcal{F}$ 的子 σ 代数，并且

$$\mathcal{F}_0 \subseteq \mathcal{F}_1 \subseteq \cdots \subseteq \mathcal{F}.$$

这列递增的子 σ 代数称为**滤过** (filtration)，可以理解为随时间增长的信息。随机变量 X_t 若对 $\mathcal{F}_t$ 可测，就称它在时刻 t 已经可知；过程 (H_t) 若 H_t 对 $\mathcal{F}_{t-1}$ 可测，就称为**可预测过程** (predictable process)。这里的“可预测”不是说 H_t 没有随机性，而是说它可以由第 t 次新噪声到来之前的信息确定。

可积过程 (M_t) 若适应于 $(\mathcal{F}_t)$ ，并满足

$$\mathbb{E}[M_t | \mathcal{F}_{t-1}] = M_{t-1}, \quad (9.10)$$

就称为**鞅** (martingale)。增量 $X_t = M_t - M_{t-1}$ 满足

$$\mathbb{E}[X_t | \mathcal{F}_{t-1}] = 0, \quad (9.11)$$

称为**鞅差** (martingale difference)。无条件零均值不够：若 X_t 可以由过去预测，累计和仍可能形成系统漂移；式 (9.11) 排除的正是这种可利用的条件平均。

示例 9.2 公平随机游走与按过去下注 设 ε_t 独立取 $\{-1, 1\}$ ，两种取值概率均为 $1/2$ ，并令 $\mathcal{F}_t = \sigma(\varepsilon_1, \dots, \varepsilon_t)$ 。公平随机游走 $S_t = \sum_{s=1}^t \varepsilon_s$ 是鞅。

现在允许下注额 H_t 根据过去结果选择，只要求 H_t 对 $\mathcal{F}_{t-1}$ 可测，并使 $H_t \varepsilon_t$ 可积。财富过程

$$M_t = M_0 + \sum_{s=1}^t H_s \varepsilon_s$$

仍是鞅，因为

$$\mathbb{E}[H_t \varepsilon_t | \mathcal{F}_{t-1}] = H_t \mathbb{E}[\varepsilon_t | \mathcal{F}_{t-1}] = 0.$$

策略可以追涨、反向或在某些历史后停止下注，但只要它不能偷看 ε_t ，就不能改变下一笔收益的条件均值。若 H_t 依赖当前尚未揭晓的 ε_t ，上面的等式便失去依据。

对平方可积鞅差，定义**可预测二次变差** (predictable quadratic variation)

$$V_t = \sum_{s=1}^t \mathbb{E}[X_s^2 | \mathcal{F}_{s-1}]. \quad (9.12)$$

它在每一步使用新增量到来之前可知的条件方差，因而能够记录实际噪声规模。与之不同， $\sum_{s=1}^t X_s^2$ 是观察后的实现二次变差。Freedman 界使用前；在其他序贯估计中也可以围绕后者构造界，但不能不加说明地互换。

9.2.2 停时与可选停止的条件

随机时刻 τ 若满足 $\{\tau \leq t\} \in \mathcal{F}_t$ 对每个 t 成立，就称为**停时** (stopping time)。到时刻 t 为止已有的信息足以判断是否已经停止；“最后一次达到最大值的时刻”通常需要看到未来，不一定是停时。

定理 9.3 有界停时的可选停止 设 $(M_t, \mathcal{F}_t)$ 为可积鞅， τ 为满足 $\tau \leq$

n 几乎必然成立的停时。则

$$\mathbb{E}[M_\tau] = \mathbb{E}[M_0].$$

证明. 写 $X_t = M_t - M_{t-1}$. 由于 τ 为停时, 事件 $\{\tau \geq t\} = \{\tau \leq t-1\}^c$ 属于 $\mathcal{F}_{t-1}$, 故其指示函数是可预测的. 又因为 $\tau \leq n$,

$$M_\tau = M_0 + \sum_{t=1}^n \mathbb{I}\{\tau \geq t\} X_t.$$

对每一项使用塔式性质与鞅差条件,

$$\mathbb{E}[\mathbb{I}\{\tau \geq t\} X_t] = \mathbb{E}[\mathbb{I}\{\tau \geq t\} \mathbb{E}[X_t | \mathcal{F}_{t-1}]] = 0.$$

有限求和后即得结论. ■

定理的证明清楚标出了有界性用途: 它把随机长度的和改写为固定的有限和. 无界停时需要额外条件, 例如鞅一致可积、停止后的变量由某个可积变量控制, 或增量有界且 $\mathbb{E}\tau < \infty$. 这些条件不能省略. 对从 0 开始的公平随机游走, 令 $\tau = \inf\{t : S_t = 1\}$. 该停时几乎必然有限, 却有 $S_\tau = 1$, 所以 $\mathbb{E}S_\tau = 1 \neq 0$; 这里 $\mathbb{E}\tau = \infty$, 不能套用有界停时定理.

9.2.3 Azuma–Hoeffding 界只使用统一增量尺度

若只知道每个鞅差的范围, 可以把独立变量的指数矩方法逐步条件化.

定理 9.4 Azuma–Hoeffding 不等式 设 $(X_t, \mathcal{F}_t)_{t=1}^n$ 为鞅差, 并且几乎必然有 $a_t \leq X_t \leq b_t$, 其中 a_t, b_t 为确定常数. 令 $S_n = \sum_{t=1}^n X_t$. 则对任意 $x > 0$,

$$\mathbb{P}(S_n \geq x) \leq \exp \left\{ -\frac{2x^2}{\sum_{t=1}^n (b_t - a_t)^2} \right\}. \quad (9.13)$$

证明. 条件 Hoeffding 引理给出, 对任意 $\lambda > 0$,

$$\mathbb{E}[\exp(\lambda X_t) | \mathcal{F}_{t-1}] \leq \exp \left\{ \frac{\lambda^2 (b_t - a_t)^2}{8} \right\}.$$

从 $t = n$ 开始反复使用塔式性质, 得到

$$\mathbb{E} \exp(\lambda S_n) \leq \exp \left\{ \frac{\lambda^2}{8} \sum_{t=1}^n (b_t - a_t)^2 \right\}.$$

Markov 不等式于是给出

$$\mathbb{P}(S_n \geq x) \leq \exp \left\{ -\lambda x + \frac{\lambda^2}{8} \sum_{t=1}^n (b_t - a_t)^2 \right\}.$$

对 λ 优化, 取 $\lambda = 4x / \sum_{t=1}^n (b_t - a_t)^2$, 便得到式 (9.13)。 ■

这个证明没有要求 X_t 彼此独立, 只要求给定过去后均值为零, 并且条件范围受控。代价是它把每一步都按最坏范围计费。若多数时刻的条件方差很小, 下一结果会给出更紧的尺度。

9.2.4 Freedman 界利用实际累积的条件方差

定理 9.5 标量 Freedman 不等式 设 $(X_t, \mathcal{F}_t)_{t \geq 1}$ 为鞅差, 且 $|X_t| \leq b$ 几乎必然成立。令

$$S_t = \sum_{s=1}^t X_s, \quad V_t = \sum_{s=1}^t \mathbb{E}[X_s^2 | \mathcal{F}_{s-1}].$$

则对任意 $x, v > 0$,

$$\mathbb{P}(\exists t \geq 1 : S_t \geq x, V_t \leq v) \leq \exp \left\{ -\frac{x^2}{2(v + bx/3)} \right\}. \quad (9.14)$$

证明. 对 $0 < \lambda < 3/b$, 标量不等式

$$e^{\lambda u} \leq 1 + \lambda u + \frac{\lambda^2 u^2}{2(1 - \lambda b/3)}, \quad |u| \leq b,$$

与 $\mathbb{E}[X_t | \mathcal{F}_{t-1}] = 0$ 共同给出

$$\mathbb{E}[e^{\lambda X_t} | \mathcal{F}_{t-1}] \leq \exp \{ \psi(\lambda) \mathbb{E}[X_t^2 | \mathcal{F}_{t-1}] \}, \quad \psi(\lambda) = \frac{\lambda^2}{2(1 - \lambda b/3)}.$$

因此

$$L_t(\lambda) = \exp \{ \lambda S_t - \psi(\lambda) V_t \}, \quad L_0(\lambda) = 1,$$

是非负超鞅。

令

$$\tau = \inf \{ t \geq 1 : S_t \geq x, V_t \leq v \}.$$

对任意整数 n , $\tau \wedge n$ 有界。对非负超鞅应用有界停时论证, $\mathbb{E} L_{\tau \wedge n}(\lambda) \leq 1$ 。

在事件 $\{\tau \leq n\}$ 上,

$$L_\tau(\lambda) \geq \exp \{ \lambda x - \psi(\lambda) v \}.$$

故

$$\mathbb{P}(\tau \leq n) \leq \exp\{-\lambda x + \psi(\lambda)v\}.$$

令 $n \rightarrow \infty$, 再取 $\lambda = x/(v + bx/3)$; 该值位于 $(0, 3/b)$, 代入后得到式 (9.14)。 ■

若 $X_1, \dots, X_n$ 相互独立、中心化且 $|X_t| \leq b$, 并且 $\sum_{t=1}^n \text{Var}(X_t) \leq v$, 则自然滤过下的 X_t 构成鞅差, 且 $V_n \leq v$ 确定成立。在式 (9.14) 中固定 $t = n$ 便得到

$$\mathbb{P}(S_n \geq x) \leq \exp\left\{-\frac{x^2}{2(v + bx/3)}\right\}.$$

这正是式 (8.24) 的同常数单侧 Bernstein 型界。因此, Freedman 界把独立变量的方差敏感界推广到了条件方差随历史变化的序贯情形。

Freedman 界同时控制所有可能时刻, 但事件中还限定了 $V_t \leq v$ 。若希望得到随观测方差自动变化的单一边界, 可以把 V_t 的可能范围分成几何区间, 对各区间使用不同 v 并分配失败概率; 更精细的方法直接混合不同 λ 。无论采用哪种构造, 序贯有效性都来自非负超鞅, 而不是把固定时刻界中的 n 替换为随机停时。

这一点可由 Ville 不等式概括: 若 L_t 为非负超鞅且 $\mathbb{E}L_0 \leq 1$, 则

$$\mathbb{P}\left(\sup_{t \geq 0} L_t \geq \frac{1}{\delta}\right) \leq \delta. \quad (9.15)$$

证明只需令 τ 为首次越过 $1/\delta$ 的时刻, 对 $\tau \wedge n$ 使用有界停时, 再令 $n \rightarrow \infty$ 。由此反演得到的**置信序列** (confidence sequence) 在同一个高概率事件上覆盖所有时刻, 因而允许根据当前数据决定何时查看或停止。固定 n 的置信区间只承诺预先指定时刻的覆盖; 反复查看直到区间排除某个值, 会改变错误概率。

同一个上穿论证还解释了后文为什么可以使用非负超鞅的极限。设 (L_t) 为非负超鞅且 $\mathbb{E}L_0 < \infty$ 。对任意有理数 $0 < a < b$, 记 $U_n[a, b]$ 为 $L_0, \dots, L_n$ 从不高过 a 到不低于 b 的完整上穿次数。在每次不高过 a 时持有一单位过程、达到 b 时卖出; 由于 (L_t) 是超鞅, 这个可预测交易策略的期望收益不大于 0。比较每次完整交易至少 $b - a$ 的路径收益与最后一次未完成交易, 得到 Doob 上穿不等式

$$(b - a)U_n[a, b] \leq \text{交易收益} + (L_n - a)^-, \quad x^- := \max\{-x, 0\}.$$

其中负部 $(L_n - a)^-$ 至多为 a , 而交易收益的期望不大于 0。取期望得到

$$(b - a)\mathbb{E}U_n[a, b] \leq \mathbb{E}(L_n - a)^- \leq a.$$

令 $n \rightarrow \infty$ 可知每个正有理区间几乎必然只被上穿有限次。若 L_t 的下极限

严格小于上极限，就能在二者之间选到一个正有理区间并产生无穷多次上穿，形成矛盾。因此 L_t 几乎必然存在扩展实数极限；再由 Fatou 引理与 $\sup_t \mathbb{E} L_t \leq \mathbb{E} L_0 < \infty$ 排除极限为正无穷。于是非负超鞅几乎必然收敛到有限随机变量。这个结论只保证路径极限存在；若还要交换极限与期望，仍需一致可积等额外条件。

9.3 自归一化集中与自适应设计

9.3.1 为什么误差要按设计矩阵衡量

标量累计和把每次噪声视为同一个方向。在线性观测中，第 t 次查询带有特征 $\mathbf{x}_t \in \mathbb{R}^d$ ，观测为

$$y_t = \langle \mathbf{x}_t, \boldsymbol{\theta}^* \rangle + \eta_t. \quad (9.16)$$

允许 $\mathbf{x}_t$ 根据 $\mathcal{F}_{t-1}$ 中的历史结果选择，但要求它在 η_t 揭晓前已经确定，也就是 $\mathbf{x}_t$ 可预测；噪声 η_t 对 $\mathcal{F}_t$ 可测。若噪声对某个 $R > 0$ 满足条件次高斯界

$$\mathbb{E}[\exp(\gamma \eta_t) \mid \mathcal{F}_{t-1}] \leq \exp\left(\frac{\gamma^2 R^2}{2}\right), \quad \gamma \in \mathbb{R}, \quad (9.17)$$

则它给定过去后均值为零，并且尾部由尺度 R 控制。

累计噪声和正则化设计矩阵分别记为

$$\mathbf{S}_t = \sum_{s=1}^t \mathbf{x}_s \mathbf{x}_s^\top, \quad \mathbf{V}_t = \mathbf{V}_0 + \sum_{s=1}^t \mathbf{x}_s \mathbf{x}_s^\top, \quad \mathbf{V}_0 > \mathbf{0}. \quad (9.18)$$

可预测性与条件中心化共同保证

$$\mathbb{E}[\mathbf{x}_t \eta_t \mid \mathcal{F}_{t-1}] = \mathbf{x}_t \mathbb{E}[\eta_t \mid \mathcal{F}_{t-1}] = \mathbf{0}.$$

因此 $(\mathbf{S}_t)$ 是向量鞅。这里没有要求 $\mathbf{x}_t$ 为确定向量，也没有要求不同 $\mathbf{x}_t$ 彼此独立；关键是它在当前噪声出现前已经由过去确定。

某个方向被反复观测时， $\mathbf{V}_t$ 沿该方向增大；从未被询问的方向只剩初始正则化。因此，自然误差尺度不是统一的欧氏球，而是

$$\|\mathbf{S}_t\|_{\mathbf{V}_t^{-1}} = \sqrt{\mathbf{S}_t^\top \mathbf{V}_t^{-1} \mathbf{S}_t}.$$

设计提供的信息越多，逆矩阵在相应方向上的权重越小。这种由随机设计自身归一化误差的形式，称为**自归一化** (self-normalized)；它与第8章中用随机权重和归一化分母构造的自归一化重要性估计不是同一个对象。

9.3.2 混合指数超鞅给出向量界

定理 9.6 向量自归一化集中界 在式 (9.16) 至 (9.18) 的条件下, 对任意 $\delta \in (0, 1)$, 以至少 $1 - \delta$ 的概率, 对所有 $t \geq 0$ 同时有

$$\|\mathbf{S}_t\|_{\mathbf{V}_t^{-1}} \leq R \sqrt{2 \log \left(\frac{\det(\mathbf{V}_t)^{1/2}}{\det(\mathbf{V}_0)^{1/2} \delta} \right)}. \quad (9.19)$$

证明. 固定任意 $\mathbf{u} \in \mathbb{R}^d$. 由于 $\mathbf{x}_t$ 对 $\mathcal{F}_{t-1}$ 可测, 在式 (9.17) 中取 $\gamma = \langle \mathbf{u}, \mathbf{x}_t \rangle$, 得到

$$\mathbb{E} \left[\exp \left\{ \langle \mathbf{u}, \mathbf{x}_t \rangle \eta_t - \frac{R^2}{2} \langle \mathbf{u}, \mathbf{x}_t \rangle^2 \right\} \middle| \mathcal{F}_{t-1} \right] \leq 1.$$

逐步相乘可知

$$L_t(\mathbf{u}) = \exp \left\{ \langle \mathbf{u}, \mathbf{S}_t \rangle - \frac{R^2}{2} \|\mathbf{u}\|_{\mathbf{V}_t - \mathbf{V}_0}^2 \right\}$$

是非负超鞅。

一个固定 $\mathbf{u}$ 只能控制一个投影方向。为同时处理所有方向, 取独立于数据的随机向量 $\mathbf{U} \sim \mathcal{N}(\mathbf{0}, R^{-2} \mathbf{V}_0^{-1})$, 并对 $L_t(\mathbf{U})$ 关于 $\mathbf{U}$ 积分。非负性允许交换条件期望与积分, 所以混合过程 $\bar{L}_t = \mathbb{E}_{\mathbf{U}} L_t(\mathbf{U})$ 仍是非负超鞅, 且 $\bar{L}_0 = 1$ 。把高斯密度与指数中的二次项合并, 配方得到

$$\bar{L}_t = \left(\frac{\det(\mathbf{V}_0)}{\det(\mathbf{V}_t)} \right)^{1/2} \exp \left\{ \frac{1}{2R^2} \|\mathbf{S}_t\|_{\mathbf{V}_t^{-1}}^2 \right\}.$$

这里行列式比来自两个高斯二次型的归一化常数, 而指数项来自配方后的中心移动。

对 $\bar{L}_t$ 使用式 (9.15), 以至少 $1 - \delta$ 的概率, 对所有 t 都有 $\bar{L}_t < 1/\delta$ 。取对数并整理, 便得到式 (9.19)。 ■

证明中的四个条件各有明确用途。条件次高斯性构造每一步指数超鞅; 特征可预测性允许在条件期望中把 $\mathbf{x}_t$ 视为已知; $\mathbf{V}_0 > \mathbf{0}$ 使高斯混合与逆矩阵从 $t = 0$ 起有定义; 行列式比累计各方向相对于初始尺度增长了多少。行列式不是把每个访问次数简单相加, 因为同一方向的重复观测与新方向的首次观测提供的信息不同。

9.3.3 从噪声界到置信椭球

取 $\mathbf{V}_0 = \lambda \mathbf{I}$, $\lambda > 0$, 并定义岭回归估计

$$\hat{\boldsymbol{\theta}}_t = \mathbf{V}_t^{-1} \sum_{s=1}^t \mathbf{x}_s y_s. \quad (9.20)$$

由式 (9.16),

$$\mathbf{V}_t(\hat{\boldsymbol{\theta}}_t - \boldsymbol{\theta}^*) = \mathbf{S}_t - \lambda \boldsymbol{\theta}^*.$$

若还知道 $\|\boldsymbol{\theta}^*\|_2 \leq B$, 三角不等式给出

$$\begin{aligned} \|\hat{\boldsymbol{\theta}}_t - \boldsymbol{\theta}^*\|_{\mathbf{V}_t} &\leq \|\mathbf{S}_t\|_{\mathbf{V}_t^{-1}} + \lambda \|\boldsymbol{\theta}^*\|_{\mathbf{V}_t^{-1}} \\ &\leq R \sqrt{2 \log \left(\frac{\det(\mathbf{V}_t)^{1/2}}{\lambda^{d/2} \delta} \right)} + \sqrt{\lambda} B =: \beta_t(\delta). \end{aligned} \quad (9.21)$$

第二个不等式使用 $\mathbf{V}_t \geq \lambda \mathbf{I}$. 因此

$$\mathcal{C}_t(\delta) = \{\boldsymbol{\theta} : \|\boldsymbol{\theta} - \hat{\boldsymbol{\theta}}_t\|_{\mathbf{V}_t} \leq \beta_t(\delta)\}$$

在同一个概率至少为 $1 - \delta$ 的事件上, 对所有 t 都包含真实参数。这是置信椭圆而不是欧氏球: 观测充分的方向较窄, 信息不足的方向较宽。

示例 9.7 二维自适应查询 设 $d = 2, \lambda = 1$, 每次只能在 $\mathbf{e}_1 = (1, 0)^\top$ 与 $\mathbf{e}_2 = (0, 1)^\top$ 中选择一个观测方向。算法可以在第 t 步比较当前椭圆在两个方向上的宽度, 并选择较宽的方向; 这个选择只依赖过去, 因而 $\mathbf{x}_t$ 可预测。

若前四次选择中 $\mathbf{e}_1$ 出现三次、 $\mathbf{e}_2$ 出现一次, 则

$$\mathbf{V}_4 = \begin{pmatrix} 4 & 0 \\ 0 & 2 \end{pmatrix}, \quad \det(\mathbf{V}_4) = 8.$$

对任意方向 $\mathbf{x}$, 椭圆给出的预测误差满足

$$|\langle \mathbf{x}, \hat{\boldsymbol{\theta}}_4 - \boldsymbol{\theta}^* \rangle| \leq \beta_4(\delta) \|\mathbf{x}\|_{\mathbf{V}_4^{-1}}.$$

因而两个坐标方向的半宽分别与 $1/2$ 和 $1/\sqrt{2}$ 成比例。第一个方向访问更多, 区间更窄; 下一次转向第二个方向是由已有信息决定的自适应设计。定理仍然适用, 因为它在每次新噪声产生之前固定当前方向, 并在一个事件上同时控制全部时刻。

这个例子也说明为什么不能把独立样本界中的 n 换成某个动作的访问次数。参数误差是向量, 不同特征方向可能相关; 置信宽度由 $\mathbf{x}^\top \mathbf{V}_t^{-1} \mathbf{x}$ 决定, 而不是只由某个坐标被访问多少次决定。行列式项又要为算法可能探索的全部方向支付复杂度。

9.3.4 自适应有效不等于任意数据依赖都有效

自归一化界允许 $\mathbf{x}_t$ 依赖 $\mathcal{F}_{t-1}$ ，不允许它依赖当前 η_t 后再伪装成预先选择。若传感器先看到当前噪声再决定是否记录， $\mathbf{x}_t \eta_t$ 的条件平均可能不再为零，指数超鞅的第一步就会失败。类似地，模型失配使 $\mathbb{E}[y_t | \mathcal{F}_{t-1}, \mathbf{x}_t]$ 不等于 $\langle \mathbf{x}_t, \boldsymbol{\theta}^* \rangle$ 时，椭圆会同时包含系统偏差与随机误差，不能继续解释为围绕同一个真实参数的置信集合。

条件次高斯性也不是有限方差的同义词。重尾噪声可能需要截断、稳健均值或只使用有限矩的其他序贯工具；直接套用式 (9.19) 会低估尾部。 λ 保证初期矩阵可逆并编码参数范数先验，但过大的 λ 会增加 $\sqrt{\lambda B}$ 偏差项。置信椭圆控制统计误差，不保证选择策略会访问所有对任务重要的方向；探索是否充分仍要由设计规则与任务目标另行证明。

9.4 随机逼近与 Markov 噪声

9.4.1 从保存平均到持续求根

若全部观测都可保存，均值求根可以在 t 步后直接使用样本平均。流式算法则希望每到一个观测只更新当前估计。对式 (9.1)，Robbins–Monro 型递推为

$$\theta^{(t+1)} = \theta^{(t)} + \alpha_t (Y_{t+1} - \theta^{(t)}), \quad t \geq 0, \quad (9.22)$$

其中确定数 $\alpha_t > 0$ 为步长。新观测高于当前估计时参数上移，低于当前估计时参数下移；若 $\mathbb{E}[Y_{t+1} | \mathcal{F}_t] = \mu$ ，则条件平均更新方向为 $\mu - \theta^{(t)}$ ，正好指向根。Markov 观测一般不满足这个条件中心化假设，后文将用 Poisson 方程分离相关波动²。

若 $\alpha_t = 1/(t+1)$ ，并从 $\theta^{(0)}$ 任意值开始，则第一次更新完全采用 Y_1 ，归纳可得

$$\theta^{(t)} = \frac{1}{t} \sum_{s=1}^t Y_s, \quad t \geq 1.$$

一般步长不再给出等权平均。较大的近期步长让算法更快响应新观测，也让噪声保留得更久；递减步长试图在持续移动与逐渐消除随机波动之间取得平衡。

更一般的随机逼近写成

$$\theta^{(t+1)} = \theta^{(t)} + \alpha_t [\bar{\mathbf{h}}(\theta^{(t)}) + \boldsymbol{\xi}_{t+1} + \mathbf{r}_{t+1}]. \quad (9.23)$$

$\bar{\mathbf{h}}$ 是平均漂移， $\boldsymbol{\xi}_{t+1}$ 是给定过去后均值为零的噪声， $\mathbf{r}_{t+1}$ 是近似、截断或分布尚未平衡产生的偏差。算法要收敛到 $\bar{\mathbf{h}}(\boldsymbol{\theta}) = \mathbf{0}$ 的稳定根，必须分别控制这三部分，不能只验证单步估计“看起来无偏”。

² H. Robbins, S. Monro, *A Stochastic Approximation Method* In The Annals of Mathematical Statistics, 1951, vol. 22, no. 3, pp. 400–407

9.4.2 步长条件分别控制移动与噪声

经典步长条件为

$$\sum_{t=0}^{\infty} \alpha_t = \infty, \quad \sum_{t=0}^{\infty} \alpha_t^2 < \infty. \quad (9.24)$$

第一项保证算法保留无限的累计移动能力；若步长和有限，初始误差可能只被缩小有限倍。第二项使有限方差噪声的加权方差可求和。取 $\alpha_t = c/(t+t_0)^\gamma$ 时，通常 $1/2 < \gamma \leq 1$ 满足这两个条件。固定步长不满足平方可和条件，适合追踪变化目标或维持稳态误差，却一般不保证迭代精确收敛到一个点。

下面先给出独立或鞅差噪声下的完整代表性证明。证明只用一个特殊的超鞅收敛引理。

引理 9.8 带可求和误差的非负超鞅 设 (Z_t) 与 (A_t) 都是关于 $(\mathcal{F}_t)$ 的非负可积适应过程， (b_t) 为非负确定数列，且以下不等式几乎必然成立：

$$\mathbb{E}[Z_{t+1} | \mathcal{F}_t] \leq Z_t - A_t + b_t.$$

若 $\sum_t b_t < \infty$ ，则 Z_t 几乎必然收敛到有限随机变量，且 $\sum_t A_t < \infty$ 几乎必然成立。

证明. 令 $r_t = \sum_{s=t}^{\infty} b_s$ ，并取 $U_t = Z_t + r_t$ 。由于 $r_t = b_t + r_{t+1}$ ，

$$\mathbb{E}[U_{t+1} | \mathcal{F}_t] \leq U_t - A_t.$$

(U_t) 是非负超鞅，故几乎必然收敛；对上式取期望并从 0 到 n 求和，得到 $\mathbb{E} \sum_{t=0}^n A_t \leq \mathbb{E} U_0$ 。令 $n \rightarrow \infty$ ，由单调收敛定理， $\mathbb{E} \sum_{t=0}^{\infty} A_t \leq \mathbb{E} U_0 < \infty$ ，所以 $\sum_t A_t < \infty$ 几乎必然成立。又因 $r_t \rightarrow 0$ ， $Z_t = U_t - r_t$ 也收敛。 ■

定理 9.9 均值求根的几乎必然收敛 设 $\mathcal{F}_t$ 包含 $\theta^{(0)}, Y_1, \dots, Y_t$ ，且 $\mathbb{E}[(\theta^{(0)} - \mu)^2] < \infty$ 。假设

$$\mathbb{E}[Y_{t+1} | \mathcal{F}_t] = \mu, \quad \mathbb{E}[(Y_{t+1} - \mu)^2 | \mathcal{F}_t] \leq \sigma^2,$$

步长满足式 (9.24)，并且从某时刻起 $0 < \alpha_t \leq 1$ 。则递推 (9.22) 满足 $\theta^{(t)} \rightarrow \mu$ 几乎必然成立。

证明. 记 $e_t = \theta^{(t)} - \mu$ ， $\xi_{t+1} = Y_{t+1} - \mu$ 。递推变为

$$e_{t+1} = (1 - \alpha_t)e_t + \alpha_t \xi_{t+1}.$$

取 T 使得对所有 $t \geq T$ 都有 $0 < \alpha_t \leq 1$ 。由初值二阶矩有限、条件二阶矩有界以及上式递推归纳可知，每个有限时刻的 $\mathbb{E}e_t^2$ 都有限，特别是 $\mathbb{E}e_T^2 < \infty$ 。以下只考虑 $t \geq T$ ；舍去有限前缀不改变极限，也不改变两组步长级数的收敛或发散性质。

条件于 $\mathcal{F}_t$ 展开平方，交叉项因 $\mathbb{E}[\xi_{t+1} | \mathcal{F}_t] = 0$ 消失：

$$\begin{aligned}\mathbb{E}[e_{t+1}^2 | \mathcal{F}_t] &= (1 - \alpha_t)^2 e_t^2 + \alpha_t^2 \mathbb{E}[\xi_{t+1}^2 | \mathcal{F}_t] \\ &\leq e_t^2 - \alpha_t e_t^2 + \alpha_t^2 \sigma^2,\end{aligned}$$

其中使用 $0 < \alpha_t \leq 1$ 得到 $(1 - \alpha_t)^2 \leq 1 - \alpha_t$ 。

令 $\mathcal{G}_k = \mathcal{F}_{T+k}$ 。关于 $(\mathcal{G}_k)$ 的移位序列，在引理 9.8 中取 $Z_k = e_{T+k}^2$ 、 $A_k = \alpha_{T+k} e_{T+k}^2$ 、 $b_k = \alpha_{T+k}^2 \sigma^2$ 。上述二阶矩归纳还验证了 Z_k 与 A_k 的可积性。平方可和条件给出 $\sum_{k=0}^{\infty} b_k < \infty$ ，所以 e_t^2 几乎必然收敛，并且 $\sum_{t=T}^{\infty} \alpha_t e_t^2 < \infty$ 。若其极限在某条样本路径上为 $L > 0$ ，则充分大的 t 都有 $e_t^2 \geq L/2$ ，从而

$$\sum_{t=T}^{\infty} \alpha_t e_t^2 \geq \frac{L}{2} \sum_{t=T}^{\infty} \alpha_t = \infty,$$

产生矛盾。因此 $L = 0$ ，即 $\theta^{(t)} \rightarrow \mu$ 。 ■

这个证明把两个步长条件的职责分开了。平方可和使噪声项 $\alpha_t^2 \sigma^2$ 可累计控制；步长和发散则排除非零极限误差。若噪声具有无限条件方差，或条件均值带有不可消失的偏差，上述递推不等式不再成立。若迭代是向量且平均漂移非线性，还要另行保证迭代不会逃向无穷远。

9.4.3 累计步长把随机更新连接到平均 ODE

定义算法时间

$$\tau_0 = 0, \quad \tau_t = \sum_{s=0}^{t-1} \alpha_s. \quad (9.25)$$

在区间 $[\tau_t, \tau_{t+1}]$ 上对 $\theta^{(t)}$ 与 $\theta^{(t+1)}$ 作线性插值，就得到连续曲线。若任意固定算法时间窗内的累计噪声与累计偏差趋于零，且 $\bar{h}$ 足够规则，那么这条插值曲线在晚期近似平均常微分方程

$$\dot{\theta}(\tau) = \bar{h}(\theta(\tau)). \quad (9.26)$$

这就是随机逼近的 **ODE 方法** (ODE method)：不要求单步随机更新接近零，而要求在与步长匹配的时间尺度上，随机波动不会改变平均轨迹的极限行为³。

对均值求根，

$$\dot{\theta} = \mu - \theta.$$

³ V. S. Borkar, *Stochastic Approximation: A Dynamical Systems Viewpoint*, Cambridge University Press, 2008

从初值 $\theta(0)$ 出发的解为

$$\theta(\tau) = \mu + (\theta(0) - \mu)e^{-\tau}. \quad (9.27)$$

因此 μ 是全局渐近稳定平衡。等价地, 取 $W(\theta) = (\theta - \mu)^2/2$, 沿 ODE 轨迹有

$$\frac{d}{d\tau} W(\theta(\tau)) = -(\theta(\tau) - \mu)^2 \leq 0,$$

且只有在根处等于零。这解释了定理 9.9 中误差平方为何是自然的势函数。

上面的标量例子只需显式解出 ODE, 便能看出平均漂移把轨迹拉向 μ 。一般向量递推还需要更完整的条件: 平均漂移的正则性保证 ODE 解适定, 迭代有界性把分析限制在可控区域, 加权噪声与累计偏差则要在固定算法时间窗内消失。满足这些条件后, 才能把离散随机插值与平均 ODE 的长期行为联系起来; 平均 ODE 若有多个稳定对象, 也不能据此断言算法到达全局最优解。有关流、稳定性与 Lyapunov 方法的系统定义和判据见第 16 章, 本章只保留这个可直接求解的标量 ODE 作为前导。

迭代有界性不能从局部稳定直接推出。常见处理包括证明一个径向无界 Lyapunov 函数, 也就是当 $\|\theta\|_2 \rightarrow \infty$ 时函数值趋于无穷, 并验证它在远处具有负漂移; 另一种做法是把每一步投影到紧凸集。投影只保证迭代有界, 还会把平均动力学改成带边界约束的投影 ODE。只有当这个投影 ODE 存在相应的稳定约束平衡, 并且噪声、步长等条件同时成立时, 算法才可能收敛到该平衡。原方程的根位于集合外这一事实本身, 既不能保证收敛, 也不能把可能的极限直接解释成原方程根在边界上的投影。

9.4.4 Poisson 方程分离 Markov 相关波动

定理 9.9 假设 $Y_{t+1} - \mu$ 给定 $\mathcal{F}_t$ 后均值为零。对 Markov 链, 这通常不成立: 例 9.1 中, $\mathbb{E}[Y_{t+1} - \mu | Z_t] = 0.7(Y_t - \mu)$ 。不过, 相关噪声仍可以借助 **Poisson 方程** (Poisson equation) 拆成鞅差与近似望远镜和。

先固定参数, 设链的转移核为 P 、平稳分布为 π , 并令 $H(\theta, z)$ 为一次随机更新。平均漂移是

$$\bar{h}(\theta) = \int H(\theta, z) \pi(dz). \quad (9.28)$$

对每个 θ , 若存在函数 g_θ 满足

$$g_\theta(z) - Pg_\theta(z) = H(\theta, z) - \bar{h}(\theta), \quad Pg_\theta(z) = \int g_\theta(z') P(z, dz'), \quad (9.29)$$

则对 $Z_{t+1} \sim P(Z_t, \cdot)$,

$$\begin{aligned} H(\theta, Z_t) - \bar{h}(\theta) &= g_\theta(Z_t) - g_\theta(Z_{t+1}) + \Delta M_{t+1}(\theta), \\ \Delta M_{t+1}(\theta) &:= g_\theta(Z_{t+1}) - P g_\theta(Z_t). \end{aligned} \quad (9.30)$$

最后一项给定 $\mathcal{F}_t$ 后均值为零，是鞅差。前两项在固定 θ 、固定步长时会望远镜消去；步长和参数缓慢变化时，分部求和会留下由 $|\alpha_t - \alpha_{t-1}|$ 以及 $\|\theta^{(t)} - \theta^{(t-1)}\|$ 控制的余项。

引理 9.10 固定有限链的加权 Poisson 分解 设 P 是有限状态空间上的不可约非周期核，且不随参数变化。令参数始终位于紧集 K , $H(\theta, z)$ 在 $K \times \mathcal{Z}$ 上有界，并关于 θ 一致 Lipschitz。考虑递推

$$\theta^{(t+1)} = \theta^{(t)} + \alpha_t H(\theta^{(t)}, Z_t),$$

其中正步长单调递减并满足式 (9.24)。则中心化 Markov 噪声的加权和

$$\sum_{t=0}^n \alpha_t [H(\theta^{(t)}, Z_t) - \bar{h}(\theta^{(t)})]$$

几乎必然收敛；特别地，它在任意向后移动的有限算法时间窗上的尾和趋于 0。

证明. 有限不可约非周期链以几何速度趋于 π 。对 $q_\theta(z) = H(\theta, z) - \bar{h}(\theta)$ ，有 $\pi q_\theta = 0$ ，故级数

$$g_\theta(z) = \sum_{k=0}^{\infty} P^k q_\theta(z)$$

绝对且一致收敛，并满足 $g_\theta - P g_\theta = q_\theta$ 。 H 的一致有界性与 Lipschitz 性质还给出常数 $G, L_g < \infty$ ，使

$$|g_\theta(z)| \leq G, \quad |g_\theta(z) - g_{\theta'}(z)| \leq L_g |\theta - \theta'|.$$

这一步是有限链和固定核提供的关键统一控制。

把式 (9.30) 代入从 m 到 n 的加权和。鞅差部分为

$$\sum_{t=m}^n \alpha_t \Delta M_{t+1}(\theta^{(t)}).$$

它的增量有界，条件二阶矩之和由常数倍 $\sum_t \alpha_t^2$ 控制，所以该鞅在 L^2 中

有界并几乎必然收敛。剩余部分可作离散分部求和：

$$\begin{aligned} & \sum_{t=m}^n \alpha_t [g_{\theta^{(t)}}(Z_t) - g_{\theta^{(t)}}(Z_{t+1})] \\ &= \alpha_m g_{\theta^{(m)}}(Z_m) - \alpha_n g_{\theta^{(n)}}(Z_{n+1}) \\ &+ \sum_{t=m+1}^n [\alpha_t g_{\theta^{(t)}}(Z_t) - \alpha_{t-1} g_{\theta^{(t-1)}}(Z_t)]. \end{aligned}$$

中间每项的绝对值不超过

$$G(\alpha_{t-1} - \alpha_t) + \alpha_{t-1} L_g |\theta^{(t)} - \theta^{(t-1)}|.$$

递推与 H 有界给出 $|\theta^{(t)} - \theta^{(t-1)}| \leq C\alpha_{t-1}$ 。第一部分按单调步长望远镜求和，第二部分由 $\sum_t \alpha_t^2 < \infty$ 控制，两个端点又因 $\alpha_t \rightarrow 0$ 而消失。因此望远镜余项和鞅项都具有有限极限，所述加权和收敛。收敛级数的尾和趋于 0，自然也覆盖任意固定算法时间长度对应的有限索引窗。 ■

例 9.1 可以显式求解这个方程。取 $H(\theta, z) = z - \theta$ ，则 $\bar{h}(\theta) = \mu - \theta$ ，方程右侧为 $z - \mu$ 。由式 (9.7)， $P(z - \mu) = 0.7(z - \mu)$ ，故可取

$$g_{\theta}(z) = \frac{z - \mu}{1 - 0.7} = \frac{10}{3}(z - \mu).$$

这里 g_{θ} 恰好与 θ 无关且有界，相关噪声的分解尤其简单。这个计算说明 Poisson 方程不是把 Markov 观测改造成独立观测，而是把累计相关误差重新组织为可由鞅工具控制的部分和边界余项。

在一般状态空间中，Poisson 方程解的存在、矩界与参数正则性需要由链的遍历性质保证。若转移核还随参数变化，即

$$Z_{t+1} \sim P_{\theta^{(t)}}(Z_t, \cdot),$$

就必须在迭代访问的参数区域上统一控制 P_{θ} 的遍历速度、平稳分布 π_{θ} 以及 g_{θ} 随参数的变化。只证明每个固定参数下的链分别遍历，不足以控制一个持续改变转移核的算法。常用的充分条件包括紧参数区域上的统一几何遍历、更新函数与 Poisson 解的适当矩界和 Lipschitz 连续性，再配合式 (9.24) 与迭代有界性。

在这些条件下，Markov 噪声随机逼近的证明路线与独立噪声相接：Poisson 分解产生加权鞅，平方可和步长控制其波动；望远镜项及参数变化余项在有限算法时间窗上消失；插值过程因而跟随

$$\dot{\theta} = \bar{h}(\theta) = \int H(\theta, z) \pi_{\theta}(dz).$$

最终收敛到哪里仍由这个平均 ODE 的稳定结构决定。混合只帮助把相关

观测替换为平均漂移加可控噪声，不会把一个不稳定平衡变成稳定平衡。

9.4.5 双时间尺度与仍需核对的边界

有些算法同时更新快变量 $\mathbf{u}^{(t)}$ 与慢变量 $\mathbf{v}^{(t)}$ ：

$$\begin{aligned}\mathbf{u}^{(t+1)} &= \mathbf{u}^{(t)} + \beta_t [\mathbf{g}(\mathbf{u}^{(t)}, \mathbf{v}^{(t)}) + \text{噪声}], \\ \mathbf{v}^{(t+1)} &= \mathbf{v}^{(t)} + \alpha_t [\mathbf{f}(\mathbf{u}^{(t)}, \mathbf{v}^{(t)}) + \text{噪声}].\end{aligned}$$

若两组步长都满足 Robbins–Monro 条件，且 $\alpha_t/\beta_t \rightarrow 0$ ，则 $\mathbf{u}$ 使用相对较大的步长，是快变量；在它的时间尺度上， $\mathbf{v}$ 近似冻结。证明先要求固定 $\mathbf{v}$ 时快 ODE 具有稳定平衡 $\mathbf{u}^*(\mathbf{v})$ ，再把慢变量的平均 ODE 写成

$$\dot{\mathbf{v}} = \mathbf{f}(\mathbf{u}^*(\mathbf{v}), \mathbf{v}).$$

步长比只建立时间尺度分离，不保证任一 ODE 稳定，也不代替噪声、Markov 混合和联合有界性条件。若两组噪声是鞅差，通常还要求其条件二阶矩在迭代访问区域内统一有界；若噪声来自 Markov 链，则要分别为快、慢更新验证相应的 Poisson 分解与统一遍历控制。平衡映射 $\mathbf{u}^*(\mathbf{v})$ 还需在慢变量访问区域内足够正则，才能把快过程的跟踪误差传入慢平均漂移。

示例 9.11 分解同一个未知均值的快慢更新 设观测满足 $\mathbb{E}[Y_{t+1} \mid \mathcal{F}_t] = \mu$ ，考虑两个标量递推

$$\begin{aligned}u^{(t+1)} &= u^{(t)} + \beta_t (Y_{t+1} - u^{(t)} - v^{(t)}), \\ v^{(t+1)} &= v^{(t)} + \alpha_t (u^{(t)} - v^{(t)}),\end{aligned}$$

其中两组步长分别满足 Robbins–Monro 条件，且 $\alpha_t/\beta_t \rightarrow 0$ 。固定慢变量 v 时，快平均 ODE 为 $\dot{u} = \mu - v - u$ ，其唯一全局稳定平衡是 $u^*(v) = \mu - v$ 。把这个平衡代入慢更新，得到

$$\dot{v} = u^*(v) - v = \mu - 2v,$$

所以慢平衡为 $v^* = \mu/2$ ，相应 $u^*(v^*) = \mu/2$ 。这个例子中，快变量先估计当前 v 尚未解释的均值部分，慢变量再调整两部分的分配；若 $\mathbb{E}[(Y_{t+1} - \mu)^2 \mid \mathcal{F}_t]$ 统一有界、初值二阶矩有限且联合迭代几乎必然有界，时间尺度论证指向 $(u^{(t)}, v^{(t)}) \rightarrow (\mu/2, \mu/2)$ 。

若只知道 $\alpha_t/\beta_t \rightarrow 0$ ，却没有快平衡的稳定性、映射 $u^*(v)$ 的正则性、慢 ODE 的稳定性或迭代有界性，上述结论均不能推出。若两组步长同阶，这个线性例子仍可另作联合系统分析，但不能再用“慢变量近似冻结”的证明。

随机逼近还有几类常见边界。若 $\sum_t \alpha_t < \infty$ ，算法可能在到达根之前停止有效移动；若 $\sum_t \alpha_t^2 = \infty$ 且噪声持续存在，随机波动可能无法消失。固定步长通常围绕稳定根形成稳态分布，误差随步长缩小，但目标变化时反而可能比递减步长更能跟踪。观测具有重尾、系统偏差或缓慢变化的均值时，需要稳健化、偏差控制或跟踪分析。参数平均可以改善某些正则模型的渐近方差，却不能修复不稳定平均漂移或缺失的访问条件。

后续动力系统与状态估计章将在状态动力学已经建立后，进一步分析一般向量 ODE、非对称线性漂移与时序差分更新的稳定性。本章提供的接口是：先写出平均漂移，再证明噪声在算法时间上可忽略，最后核对平均动力学的稳定结构。任何一步缺失，都不能仅凭损失曲线平滑或样本数量增加声称随机更新已经收敛。

9.5 本章小结

当观测沿时间相关或由过去自适应选择时，独立样本分析失效的位置并不相同。Markov 链用转移核描述当前状态怎样影响下一步；平稳分布只保证从该分布出发后保持不变，不可约性、周期与返回条件决定能否从指定初态接近它。时间平均还受到自相关影响，所以记录数不能直接解释为独立信息量。有限链的路径条件也不能原样搬到一般状态空间；正 Harris 常返和几何遍历分别提供长期平均与更强误差分析的入口。

鞅把关注点从状态依赖转向条件不可预测性。可预测策略可以根据过去改变每一步的尺度，只要新增量给定过去后均值为零，累计过程仍可用指数超鞅分析。Azuma-Hoeffding 按最坏增量范围计费，Freedman 进一步利用可预测条件方差。停时与 Ville 不等式解释了序贯保证的来源，也说明固定时刻概率界为何不能直接支持反复查看后再停止。

带可预测特征的向量鞅需要按设计矩阵归一化。高斯混合把所有投影方向合成一个非负超鞅，由此得到同时覆盖全部时刻的自归一化界和置信椭圆。椭圆会随已经选择的方向收缩，因此能够适应过去驱动的设计；它仍要求当前特征在当前噪声揭晓前确定，并要求条件尾部与线性模型假设成立。

均值求根把这些误差工具放入持续更新。步长和发散保留到达根所需的累计移动，平方和收敛控制有限方差噪声，平均漂移的稳定性决定更新指向哪里，迭代有界性保证局部分析不会失去适用范围。Markov 噪声可借 Poisson 方程分成鞅差与近似望远镜项，再由算法时间插值接入平均 ODE；受参数控制的链和双时间尺度还需统一遍历、正则性与稳定条件。由此，相关平均、自适应置信和随机逼近共同回答了章首问题：数据可以依赖过去，但证明必须准确保留条件平均、信息增长和长期动力学之间的关系。第 10 章将回到有限观测的推断问题，区分可识别性、估计误差、区间与检验，并说明抽样制度怎样决定这些结论所针对的总体。

数理统计

概率论假定分布已经给定，再计算事件概率和随机变量的平均。本章把方向反过来：我们只看到有限个带噪读数

$$Y_i = \theta + \varepsilon_i, \quad i = 1, \dots, n,$$

却希望认识未知的信号、噪声分布，乃至下一次读数。样本平均看似给出了答案，但它立即留下几项问题。读数是否来自希望推广到的总体？两个不同信号会不会产生相同的观测分布？异常读数会怎样改变结论？反复选择模型和查看结果后，原有的不确定性说明是否仍然可信？

数理统计（mathematical statistics）研究如何由有限观测推断产生观测的规律，以及如何量化这种推断的不确定性。本章先固定推断目标与抽样制度，再把点估计、区间、检验和预测放进同一误差语言。随后讨论重采样、选择后的证据、概率校准、非参数方法与模型证据，并回到数据取得过程。整章都要区分三件事：数据里有什么信息，方法在什么假设下使用这些信息，以及结论究竟指向哪个总体。

10.1 统计模型与推断目标

10.1.1 模型、统计量与目标泛函

统计模型（statistical model）是一族候选分布

$$\mathcal{P} = \{P_{\vartheta} : \vartheta \in \Theta\}.$$

这些分布定义在同一个可测观测空间上，参数 ϑ 是描述候选分布的未知索引。观测 $\mathbf{Y} = (Y_1, \dots, Y_n)$ 由其中某个分布产生，但真实索引不可见。参数未必是一个物理常数；它也可以是一组回归系数、一个混合比例，或者无限维的分布函数。

统计量（statistic）是只依赖样本的可测函数 $T(\mathbf{Y})$ 。当统计量被设计来逼近某个未知目标 $\tau(\vartheta)$ 时，它称为**估计量**（estimator），通常记为 $\hat{\tau}$ 。在一

批已经观测的数据 $\mathbf{y}$ 上算出的 $\hat{\tau}(\mathbf{y})$ 是**估计值** (estimate)。参数属于模型, 估计量在重复抽样中是随机变量, 估计值则是一次计算得到的数; 混淆三者会使“偏差”和“不确定性”失去对象。

推断目标可以有不同层次。估计 θ 是在参数空间中找一个点; 估计分布函数 $F(\mathbf{y})$ 是在函数空间中恢复整体规律; 预测未来观测 Y_{n+1} 则还要保留新噪声。即使都输出一个数, 它们回答的也不是同一个问题。例如 $\bar{Y}$ 可估计位置 θ , 而预测下一次读数还需要噪声尺度。一般地, 目标写成映射 $\tau: \Theta \rightarrow \mathcal{A}$, 其中 $\mathcal{A}$ 可以是标量、向量、函数或概率分布。能够只由可观察分布决定的目标也可进一步写成分布泛函。估计误差还必须配合损失 $\ell: \mathcal{A} \times \mathcal{A} \rightarrow [0, \infty]$ 解释; 向量目标的坐标平方误差、总平方误差和某个方向上的误差是不同口径, 不能只写“估计准确”。

在有限方差位置模型 $Y_i = \theta + \varepsilon_i$ 中, 若误差独立、均值为零且方差为 σ^2 , 则

$$\mathbb{E}_{\theta}[\bar{Y}] = \theta + \frac{1}{n} \sum_{i=1}^n \mathbb{E}[\varepsilon_i] = \theta, \quad \text{Var}_{\theta}(\bar{Y}) = \frac{1}{n^2} \sum_{i=1}^n \text{Var}(\varepsilon_i) = \frac{\sigma^2}{n}.$$

无偏性来自零均值, $1/n$ 方差缩减还使用了独立性; 若误差相关, 方差中必须保留协方差项。

10.1.2 识别、等价模型与推断边界

数据充足之前还要问目标能否由观测区分。若

$$P_{\vartheta_1} = P_{\vartheta_2} \implies \tau(\vartheta_1) = \tau(\vartheta_2),$$

就称目标 τ 在模型中是**可识别的** (identifiable)。取 $\tau(\vartheta) = \vartheta$ 时, 这一定义才退化为参数可识别。可识别性是总体分布层面的性质, 不是有限样本算法的表现。

示例 10.1 混合成分的标签交换 设观测来自二成分高斯混合

$$p(\mathbf{y}) = \pi \phi(\mathbf{y}; \mu_1, \sigma^2) + (1 - \pi) \phi(\mathbf{y}; \mu_2, \sigma^2).$$

把 (π, μ_1, μ_2) 换成 $(1 - \pi, \mu_2, \mu_1)$ 不改变分布。若“第一成分”只表示编号, 参数便有两种等价表示; 添加 $\mu_1 < \mu_2$ 之类约束可以固定表示, 却没有创造新的观测信息。

另一种失败来自来源一起出错。若所有温度计都有未知共同偏移 b , 模型为 $Y_i = \theta + b + \varepsilon_i$, 观测只识别 $\theta + b$, 不能分别识别 θ 和 b 。增加同型号温度计会减小随机噪声, 却不会消除共同偏差。由此可见, “有很多数据”“目标可识别”和“目标容易准确估计”是三项不同判断。

不可识别还直接限制任何估计程序。若 $P_{\vartheta_1} = P_{\vartheta_2}$ 但 $\tau(\vartheta_1) \neq \tau(\vartheta_2)$, 取两目标值距离的三分之一为 $\epsilon > 0$ 。任何只依赖样本的估计量 $\hat{\tau}_n$ 在两种机制下具有相同分布, 因而不可能同时满足

$$\mathbb{P}_{\vartheta_j} \{ \|\hat{\tau}_n - \tau(\vartheta_j)\| < \epsilon \} \longrightarrow 1, \quad j = 1, 2.$$

因为两个半径为 ϵ 的球不相交, 同一个估计量分布不可能把趋近于一的概率同时赋给它们。这证明了: 不可识别目标不能靠增加同类样本在全部等价机制下一致恢复。

10.2 抽样制度与目标总体

10.2.1 总体、抽样与权重

统计结论必须先回答“想对谁成立”。**目标总体** (target population) 是推断希望覆盖的对象、时间和条件的集合; **抽样制度** (sampling regime) 描述观测如何从这些对象产生。若样本只来自工作日的一个传感器, 模型本身不能把结论自动推广到周末或另一批设备。

独立同分布抽样把每个 Y_i 视为来自同一分布的独立重复。配对抽样则把 $(Y_{i,A}, Y_{i,B})$ 视为一个单位, 例如同一对象在两种条件下的读数。此时差值 $D_i = Y_{i,A} - Y_{i,B}$ 才是独立单位; 把两列拆成 $2n$ 个独立记录会丢失配对信息。分层抽样预先按群组分别抽取, 成组抽样则一次抽取整个设备、班级或用户群。两者的独立单位和加权方式不同。

10.2.2 条件分母、相关性与信息量

配对的收益取决于对内协方差:

$$\text{Var}(D_i) = \text{Var}(Y_{i,A}) + \text{Var}(Y_{i,B}) - 2 \text{Cov}(Y_{i,A}, Y_{i,B}).$$

正协方差会降低差值方差, 负协方差则可能使配对更差; “同一对象测两次”本身并不保证精度提高。

设目标总体中群组 g 的比例为 π_g , 群组均值为 μ_g , 则总体均值为

$$\mu = \sum_g \pi_g \mu_g.$$

总体指标可能很好, 却掩盖某个小群组的严重误差。若群组中有 n_g 个独立 Bernoulli 结果, 样本比率 $\hat{p}_g$ 的方差为

$$\text{Var}(\hat{p}_g) = \frac{p_g(1 - p_g)}{n_g}.$$

这里把 n_g 视为固定正整数。若群组样本数 $N_g = \sum_i \mathbb{I}\{G_i = g\}$ 也是随机的, 则 $\hat{p}_g$ 只在 $N_g > 0$ 时有定义, 且上述方差是给定 N_g 后的条件方差; 无条件误差还要平均随机分母, 并处理 $N_g = 0$ 事件。不确定性由实际相关分母决定, 而不是总样本量 n 。报告群组公平性或来源质量时, 应同时报告分母、抽样方式和区间, 不能只排列百分比。

已知入样概率时, 权重可以把抽样分布重新接回目标总体。令 $S \in \{0, 1\}$ 表示一个总体对象是否入样, $\rho(Z) = \mathbb{P}(S = 1 \mid Z)$, 并假设 $S \perp Y \mid Z$, $\rho(Z) > 0$ 以及 $\mathbb{E}[|Y|/\rho(Z)] < \infty$ 。条件期望给出

$$\mathbb{E}\left[\frac{SY}{\rho(Z)}\right] = \mathbb{E}\left[\frac{\mathbb{E}[S \mid Y, Z]Y}{\rho(Z)}\right] = \mathbb{E}[Y].$$

这条逆概率恒等式恢复的是明确的总体平均。若某一区域 $\rho(Z) = 0$, 或者入样在给定 Z 后仍依赖未观测的 Y , 等式便不能由现有数据推出。

记录数也不等于独立信息量。若同一来源复制一条记录十次, 样本平均的显示分母增大, 实际信息却没有增加。时间序列中的相邻读数可能共享漂移; 群组内记录可能共享设备偏差。这类依赖应通过按群组建模、块抽样或第 9 章的相关过程工具处理, 而不能继续套用独立样本方差。

时间抽样还会改变目标本身。若传感器每分钟记录一次, 而目标是“一天中随机时刻的平均读数”, 等间隔采样与目标一致; 若只在告警后加密采样, 朴素平均就会过度代表异常时段。一种修正方式是记录每个时段被抽中的概率并作逆概率加权, 但这要求所有目标时段都有正的入样概率。完全未覆盖的夜间时段不能靠增大已有权重恢复。抽样日志因此也是统计数据的一部分。

抽样制度与分析单位应在看结果前确定。假设十台设备各产生一千条记录, 而处理实际随机分配给设备, 那么有效随机化单位是十台设备, 不是一万条记录。记录内噪声可以帮助估计每台设备的均值, 却不能把处理效应的独立单位扩充到一万。这个区别会同时影响标准误、置换方式和训练测试划分。

10.3 似然、估计方程与稳健性

10.3.1 似然与充分统计量

给定观测 $\mathbf{y}$ 后, 似然 (likelihood)

$$L(\theta; \mathbf{y}) = p_\theta(\mathbf{y})$$

相对于模型共同的参考测度定义, 把数据固定, 把参数看作待比较的变量。似然不是参数的概率分布; 只有再指定先验并归一化后, 才得到后验分布。

最大似然估计选择 $\hat{\vartheta}_{\text{MLE}} \in \arg \max_{\vartheta} L(\vartheta; \mathbf{y})$, 通常等价于最小化负对数似然¹。

对 $Y_i \stackrel{\text{iid}}{\sim} \mathcal{N}(\theta, \sigma^2)$, 且 σ^2 已知,

$$-\log L(\theta; \mathbf{y}) = \frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \theta)^2 + C.$$

对 θ 求导并令其为零, 得到 $\hat{\theta} = \bar{y}$ 。同一个样本平均也可由矩估计得到: 总体矩 $\mathbb{E}_{\theta}[Y] = \theta$, 于是令样本矩 $\bar{Y}$ 等于总体矩。似然法依赖完整分布形式, 矩估计只使用选定矩条件。

“令导数为零”只寻找内点候选, 不保证最大值存在或唯一。例如独立 Bernoulli 观测的似然为

$$L(p; \mathbf{y}) = p^{\sum_i y_i} (1-p)^{n-\sum_i y_i}, \quad p \in [0, 1].$$

当样本同时含有 0 和 1 时, 唯一最大值是样本比例; 全为 1 或全为 0 时, 最大值分别落在边界 $p = 1$ 或 $p = 0$ 。若错误地把参数域写成开区间 $(0, 1)$, 边界数据甚至只有上确界而没有最大似然估计。

充分统计量 (sufficient statistic) 是在给定它之后, 样本其余部分不再携带关于参数的信息。若密度可分解为

$$p_{\vartheta}(\mathbf{y}) = g_{\vartheta}(T(\mathbf{y}))h(\mathbf{y}),$$

则因子分解定理说明 T 对 ϑ 充分。直观地说, 给定 $T(\mathbf{Y}) = t$ 后, 条件密度中的参数因子在归一化时抵消, 剩余分布不含 ϑ 。反过来, 在存在相应条件密度的受支配模型中, 若 $\mathbf{Y} | T = t$ 的条件密度 $k(\mathbf{y} | t)$ 不依赖参数, 则

$$p_{\vartheta}(\mathbf{y}) = p_{\vartheta}^T(T(\mathbf{y}))k(\mathbf{y} | T(\mathbf{y})),$$

也得到所需分解。高斯位置模型中, 已知方差时 $\sum_i Y_i$ 充分。充分性是相对于指定模型而言的; 模型失配后, 压缩掉的部分可能正好暴露失配。

10.3.2 M 估计、矩估计与仿真目标

更一般地, **M 估计** (M-estimation) 最小化样本准则

$$\hat{\vartheta} \in \arg \min_{\vartheta \in \Theta} \frac{1}{n} \sum_{i=1}^n \rho(Y_i, \vartheta).$$

可微时, 一阶条件是估计方程

$$\frac{1}{n} \sum_{i=1}^n \psi(Y_i, \hat{\vartheta}) = 0, \quad \psi(y, \vartheta) = \nabla_{\vartheta} \rho(y, \vartheta).$$

¹ A. W. van der Vaart, *Asymptotic Statistics*, Cambridge University Press, 1998

平方损失给出 $\psi(y, \theta) = \theta - y$, 每个残差的作用随绝对值线性增长。绝对损失 $\rho(y, \theta) = |y - \theta|$ 的总体最小点则是中位数: 目标函数的左右方向导数分别由 $\mathbb{P}(Y < \theta)$ 与 $\mathbb{P}(Y > \theta)$ 决定, 最优条件是 $\mathbb{P}(Y \leq \theta) \geq 1/2$ 且 $\mathbb{P}(Y \geq \theta) \geq 1/2$ 。因此平方与绝对准则即使使用同一批位置数据, 也在估计不同的总体泛函。

M 估计的一致性需要把经验准则与总体准则连接起来。记

$$Q_n(\vartheta) = \frac{1}{n} \sum_{i=1}^n \rho(Y_i, \vartheta), \quad Q(\vartheta) = \mathbb{E}[\rho(Y, \vartheta)].$$

假设 Θ 紧, Q 在唯一点 ϑ^* 取得最小值, 并且该最小值分离, 即对每个 $\epsilon > 0$,

$$\inf_{\|\vartheta - \vartheta^*\| \geq \epsilon} Q(\vartheta) > Q(\vartheta^*).$$

若 $\sup_{\vartheta \in \Theta} |Q_n(\vartheta) - Q(\vartheta)| \xrightarrow{\mathbb{P}} 0$, 且近似优化误差

$$Q_n(\hat{\vartheta}_n) - \inf_{\vartheta \in \Theta} Q_n(\vartheta) = o_{\mathbb{P}}(1),$$

其中 $o_{\mathbb{P}}(1)$ 表示该随机误差依概率趋于零, 则 $\hat{\vartheta}_n \xrightarrow{\mathbb{P}} \vartheta^*$ 。证明只需比较准则: 在任意固定的 ϵ 球外, 总体准则有正间隔; 当一致偏差和优化误差都小于该间隔的适当分数时, 经验近似最小点不可能位于球外。若参数空间不紧, 则必须另证估计点不会逃向无穷远; 若总体最小点不唯一, 结论只能指向最小点集合。

若真实分布 Q 不属于 $\mathcal{P}$, 最大似然估计通常趋向使

$$\vartheta^* \in \arg \max_{\vartheta} \mathbb{E}_Q[\log p_{\vartheta}(Y)]$$

最大的**伪真参数** (pseudo-true parameter)。它是模型族中按对数损失最接近真实分布的点, 不必等于科学问题中的真实量。估计量收敛并不自动证明模型正确。

10.3.3 稳健损失与影响函数

为了限制异常残差的作用, 可使用阈值 $c > 0$ 的 Huber 损失

$$\rho_c(r) = \begin{cases} r^2/2, & |r| \leq c, \\ c|r| - c^2/2, & |r| > c, \end{cases} \quad \psi_c(r) = \begin{cases} r, & |r| \leq c, \\ c \operatorname{sign}(r), & |r| > c. \end{cases}$$

这里 $\psi_c(r) = \rho'_c(r)$ 是损失对残差 r 的导数。由于 $\nabla_{\theta} \rho_c(y - \theta) = -\psi_c(y - \theta)$, 位置估计的参数梯度方程整体乘以 -1 后, 等价地写成 $\sum_i \psi_c(y_i - \hat{\theta}) = 0$ 。小残差仍按平方损失处理, 大残差的贡献被截在 $\pm c$ 。代价是: 即使高斯模

型完全正确，较小的 c 也会舍弃一部分有效幅度信息。

局部污染的影响可由**影响函数** (influence function) 刻画。设统计泛函 $T(P)$ 由

$$\mathbb{E}_P[\psi(Y, T(P))] = 0$$

定义，并令 $P_\epsilon = (1 - \epsilon)P + \epsilon\Delta_z$ 。记 $A = \mathbb{E}_P[\partial_\theta \psi(Y, T(P))] \neq 0$ 。假设估计方程在 $\epsilon = 0$ 附近可微，微分可移入期望，且所跟踪的根在局部唯一。对 $\mathbb{E}_{P_\epsilon}[\psi(Y, T(P_\epsilon))] = 0$ 在 $\epsilon = 0$ 处隐式求导，得到

$$0 = -\mathbb{E}_P[\psi(Y, T(P))] + \psi(z, T(P)) + AT'(0),$$

第一项为零，因此

$$\text{IF}(z; T, P) = T'(0) = -A^{-1}\psi(z, T(P)). \quad (10.1)$$

平方损失的位置影响随 z 无界，Huber 得分则有界。多维参数时 A 是估计方程的 Jacobian 矩阵；经验风险中它常表现为 Hessian 矩阵近似，但只有可微、局部可逆且估计根稳定时，这种近似才成立。影响函数只描述污染比例在零附近的一阶敏感性，不是任意污染比例下的误差上界；在回归中，截断残差也不会自动限制极端输入产生的高杠杆影响。

10.4 偏差、方差与估计效率

10.4.1 均方误差与一致性

估计量的误差既来自系统偏移，也来自样本波动。对标量目标 θ ,

$$\begin{aligned} \mathbb{E}[(\hat{\theta} - \theta)^2] &= \mathbb{E}[(\hat{\theta} - \mathbb{E}\hat{\theta} + \mathbb{E}\hat{\theta} - \theta)^2] \\ &= \text{Var}(\hat{\theta}) + (\mathbb{E}[\hat{\theta}] - \theta)^2. \end{aligned} \quad (10.2)$$

交叉项期望为零，因而均方误差等于方差加偏差平方。无偏不等于误差最小；少量偏差可能换来更大的方差下降。

更一般地，给定损失 ℓ ，估计量的**风险** (risk) 是

$$R_\theta(\hat{\tau}) = \mathbb{E}_\theta[\ell(\hat{\tau}(\mathbf{Y}), \tau(\theta))].$$

若 $\theta \in \mathbb{R}^d$ 并使用总平方误差，则

$$\mathbb{E}\|\hat{\theta} - \theta\|_2^2 = \text{tr}\{\text{Cov}(\hat{\theta})\} + \|\mathbb{E}\hat{\theta} - \theta\|_2^2.$$

这不是每个坐标风险的最大值，也不是任意方向风险。

在高斯位置例子中, 取固定中心 μ_0 并令 $\tilde{\theta} = a\bar{Y} + (1-a)\mu_0$, 则

$$\text{MSE}_{\tilde{\theta}}(\tilde{\theta}) = \frac{a^2\sigma^2}{n} + (1-a)^2(\mu_0 - \theta)^2.$$

当 θ 接近 μ_0 时, 某些 $a < 1$ 可比无偏的样本均值具有更小有限样本均方误差; 远离中心时, 收缩偏差又可能占主导。比较结论必须固定目标、样本量和损失。

当任意 $\epsilon > 0$ 都满足 $\mathbb{P}_{\theta}(|\hat{\theta}_n - \theta| > \epsilon) \rightarrow 0$ 时, 称估计量 **一致** (consistent)。一致性只描述样本量趋于无穷的极限, 不给出当前样本的误差, 也不排除有限样本偏差。若 $\mathbb{E}_{\theta}[(\hat{\theta}_n - \theta)^2] \rightarrow 0$, 则称为均方一致; Markov 不等式说明均方一致推出依概率一致, 反向结论没有额外一致可积性时并不成立。对某些满足额外正则条件的估计量, 还能进一步证明

$$\sqrt{n}(\hat{\theta}_n - \theta) \xrightarrow{d} \mathcal{N}(0, V).$$

这项性质称为渐近正态, 它需要另行建立, 并不由一致性自动推出。

概率有界 (bounded in probability) 把“随机量不会随 n 逃向无穷”写成可检验的概率条件。若对每个 $\epsilon > 0$, 都存在有限常数 M 和整数 n_0 , 使

$$\sup_{n \geq n_0} \mathbb{P}(|X_n| > M) < \epsilon,$$

就记 $X_n = O_{\mathbb{P}}(1)$ 。若 $X_n \rightarrow_{\mathbb{P}} 0$, 则记 $X_n = o_{\mathbb{P}}(1)$ 。依分布收敛的序列必然概率有界, 但 $O_{\mathbb{P}}(1)$ 本身不指定唯一极限分布。

10.4.2 渐近正态与 Delta 方法

样本均值给出渐近正态的基本例子。若 $Y_1, \dots, Y_n$ 独立同分布, 且 $\mathbb{E}[Y_i] = \theta$, $0 < \text{Var}(Y_i) = \sigma^2 < \infty$, 则中心极限定理给出

$$\sqrt{n}(\bar{Y} - \theta) \xrightarrow{d} \mathcal{N}(0, \sigma^2).$$

因此均值的渐近正态只需要有限方差, 不要求观测本身服从高斯分布; 在高斯位置模型中, 这个正态分布关系对每个有限 n 已经精确成立。

定理 10.2 Slutsky 定理 若 $X_n \xrightarrow{d} X$, 且 $Y_n \xrightarrow{\mathbb{P}} c$, 其中 c 为常数, 则

$$X_n + Y_n \xrightarrow{d} X + c, \quad X_n Y_n \xrightarrow{d} cX.$$

若 $c \neq 0$, 还有 $X_n/Y_n \xrightarrow{d} X/c$ 。特别地, 若 $R_n = o_{\mathbb{P}}(1)$, 则 $X_n + R_n \xrightarrow{d} X$ 。

Slutsky 定理允许把收敛到常数的标准误、归一化因子或余项代入渐近

分布。它不表示两个一般随机极限可以忽略联合分布；关键条件是其中一个序列依概率收敛到常数。

定理 10.3 Delta 方法 若 $\sqrt{n}(\hat{\theta}_n - \theta) \xrightarrow{d} \mathcal{N}(0, V)$, 且 g 在 θ 处可微, 则

$$\sqrt{n}(g(\hat{\theta}_n) - g(\theta)) \xrightarrow{d} \mathcal{N}(0, g'(\theta)^2 V).$$

证明. 记

$$Z_n = \sqrt{n}(\hat{\theta}_n - \theta), \quad Z \sim \mathcal{N}(0, V).$$

先补出证明所需的两条概率阶规则。由 $Z_n \xrightarrow{d} Z$, 对任意 $\epsilon > 0$, 可取充分大的 M 使 $\mathbb{P}(|Z| \geq M) < \epsilon/2$ 。依分布收敛的闭集上界给出

$$\limsup_{n \rightarrow \infty} \mathbb{P}(|Z_n| \geq M) \leq \mathbb{P}(|Z| \geq M) < \epsilon/2,$$

所以 $Z_n = O_{\mathbb{P}}(1)$ 。此外, 若 $A_n = o_{\mathbb{P}}(1), B_n = O_{\mathbb{P}}(1)$, 则对任意 $\eta, \epsilon > 0$, 先取 M 使大样本下 $\mathbb{P}(|B_n| > M) < \epsilon/2$, 再取充分大的 n 使 $\mathbb{P}(|A_n| > \eta/M) < \epsilon/2$ 。于是

$$\mathbb{P}(|A_n B_n| > \eta) \leq \mathbb{P}(|B_n| > M) + \mathbb{P}(|A_n| > \eta/M) < \epsilon,$$

即 $o_{\mathbb{P}}(1)O_{\mathbb{P}}(1) = o_{\mathbb{P}}(1)$ 。

特别地, $\hat{\theta}_n - \theta = n^{-1/2}Z_n = o_{\mathbb{P}}(1)$, 所以估计量依概率一致。Taylor 展开给出

$$g(\hat{\theta}_n) - g(\theta) = g'(\theta)(\hat{\theta}_n - \theta) + r_n(\hat{\theta}_n - \theta),$$

其中一致性与可微性保证 $r_n = o_{\mathbb{P}}(1)$ 。乘以 $\sqrt{n}$ 后, 余项是 $r_n Z_n = o_{\mathbb{P}}(1)$ 。主项由假设依分布收敛, 再用 Slutsky 定理即得结论。■

回到上述有限方差样本均值, 若 $\theta > 0$, 取 $g(\theta) = \log \theta$, 便有渐近方差 σ^2/θ^2 。若 $g'(\theta) = 0$ 或 g 在目标点不可微, 一阶 Delta 方法不再给出正确尺度, 需要更高阶展开或别的方法。

一般估计方程也给出一个正则渐近式。若 $\mathbb{E}[\psi(Y, \theta_0)] = 0$, 记

$$A = \mathbb{E}[\partial_{\theta} \psi(Y, \theta_0)], \quad B = \text{Var}(\psi(Y, \theta_0)),$$

且一致性、可微性、矩条件和中心极限定理所需条件成立, 则在 θ_0 附近展开样本估计方程可得

$$\sqrt{n}(\hat{\theta} - \theta_0) = -A^{-1} \frac{1}{\sqrt{n}} \sum_{i=1}^n \psi(Y_i, \theta_0) + o_{\mathbb{P}}(1),$$

故极限方差为 $A^{-2}B$ 。多维情形相应为 $A^{-1}B(A^{-1})^{\top}$, 常称夹心协方差。模

型正确的光滑似然在正则条件下可用信息恒等式化简它；模型失配时 A 与 B 通常不再是同一个信息量，夹心两侧不能省略。

10.4.3 得分、Fisher 信息与效率界

Fisher 信息 (Fisher information) 衡量观测分布对参数局部变化的敏感程度。下面固定一组足以支持常用恒等式的正则条件：参数位于开区间，所有密度相对于共同参考测度定义并具有共同正支持；密度关于参数二次连续可微；目标参数邻域内的一、二阶密度导数分别受可积函数控制；得分二阶矩有限。对得分 $s_\theta(Y) = \partial_\theta \log p_\theta(Y)$ ，这些条件允许交换微分与积分，于是

$$\mathbb{E}_\theta[s_\theta(Y)] = \int \partial_\theta p_\theta(y) dy = \partial_\theta 1 = 0.$$

再由 $\partial_\theta^2 \log p_\theta = (\partial_\theta^2 p_\theta)/p_\theta - s_\theta^2$ 积分，得到

$$\mathcal{I}(\theta) = \mathbb{E}_\theta[s_\theta(Y)^2] = -\mathbb{E}_\theta[\partial_\theta^2 \log p_\theta(Y)].$$

高斯位置观测的单样本信息为 $1/\sigma^2$ ， n 个独立观测的信息相加为 n/σ^2 。下文记整批样本的得分为 $s_\theta(\mathbf{Y}) = \sum_{i=1}^n s_\theta(Y_i)$ 。

定理 10.4 Cramér-Rao 下界 设 $Y_1, \dots, Y_n$ 独立同分布于 p_θ ，并且上述正则条件成立且单样本 Fisher 信息满足 $0 < \mathcal{I}(\theta) < \infty$ 。若 $\hat{\tau}$ 对可微目标 $\tau(\theta)$ 无偏、二阶矩有限，且其期望可对参数求导并移入积分，则

$$\text{Var}_\theta(\hat{\tau}) \geq \frac{\tau'(\theta)^2}{n\mathcal{I}(\theta)}.$$

证明. 由无偏性 $\mathbb{E}_\theta[\hat{\tau}] = \tau(\theta)$ 对参数求导，并把导数移入积分，得到

$$\tau'(\theta) = \mathbb{E}_\theta[(\hat{\tau} - \tau(\theta))s_\theta(\mathbf{Y})].$$

Cauchy-Schwarz 不等式给出

$$\tau'(\theta)^2 \leq \text{Var}_\theta(\hat{\tau}) \text{Var}_\theta(s_\theta(\mathbf{Y})) = \text{Var}_\theta(\hat{\tau}) n \mathcal{I}(\theta),$$

整理即得结论。 ■

这个界不是所有估计问题的普遍极限。参数位于边界、支持依赖参数、模型不可识别或 Fisher 信息奇异时，证明中的求导和除法可能失效；有偏估计量也要使用相应的偏差版本。对 $\theta \in \mathbb{R}^p$ 和可微目标 $\tau(\theta) \in \mathbb{R}^q$ ，向量参数的正则版本为

$$\text{Cov}_\theta(\hat{\tau}) \geq \mathbf{J}_\tau(\theta) \mathcal{I}_n(\theta)^{-1} \mathbf{J}_\tau(\theta)^\top,$$

其中 $\mathbf{J}_\tau \in \mathbb{R}^{q \times p}$ 是目标映射的 Jacobian, $\mathcal{I}_n$ 是整批样本的 Fisher 信息矩阵。这里要求信息矩阵可逆, 但 Jacobian 可以是矩形或降秩矩阵; 估计参数本身时 $\tau(\theta) = \theta$, 故 $\mathbf{J}_\tau = \mathbf{I}_p$ 。矩阵结论也不能由逐坐标标量界直接拼接得到。

10.5 Bayes 估计与层次共享

10.5.1 先验、后验与后验预测

频率学派把参数固定而把样本看作随机。Bayes 方法另给参数指定先验 $\pi(\theta)$, 观测后用

$$\pi(\theta | \mathbf{y}) = \frac{p(\mathbf{y} | \theta)\pi(\theta)}{\int p(\mathbf{y} | u)\pi(u) du}$$

得到**后验分布** (posterior distribution)。它把似然提供的数据证据与先验假设合并。这个公式要求分母, 即模型证据, 严格为正且有限; 否则右侧不能定义概率分布。

后验均值最小化后验平方损失。事实上, 对任意行动 a , 令 $m = \mathbb{E}[\theta | \mathbf{y}]$, 则

$$\mathbb{E}[(\theta - a)^2 | \mathbf{y}] = \text{Var}(\theta | \mathbf{y}) + (a - m)^2.$$

后验中位数则最小化后验绝对损失, 其理由与前文总体中位数的左右方向导数相同。最大后验估计只选择相对于指定参考测度的密度峰值; 非线性重参数化会引入 Jacobian 因子, 因此峰值位置一般不保持不变。三种 Bayes 行动不必相同。

设

$$Y_i | \theta \stackrel{\text{iid}}{\sim} \mathcal{N}(\theta, \sigma^2), \quad \theta \sim \mathcal{N}(\mu_0, \tau_0^2).$$

配方后得到共轭更新

$$\theta | \mathbf{y} \sim \mathcal{N}(\mu_n, \tau_n^2), \quad \tau_n^{-2} = \tau_0^{-2} + n\sigma^{-2},$$

$$\mu_n = \tau_n^2 \left(\frac{\mu_0}{\tau_0^2} + \frac{n\bar{y}}{\sigma^2} \right).$$

后验均值是先验均值与样本均值按精度加权的折中。若要预测新读数, 还要积分掉参数:

$$Y_{n+1} | \mathbf{y} \sim \mathcal{N}(\mu_n, \sigma^2 + \tau_n^2).$$

其中 τ_n^2 是参数不确定性, σ^2 是新观测自身的噪声。

离散比例也有同样的共轭结构。若 $Y_i | p \stackrel{\text{iid}}{\sim} \text{Bernoulli}(p)$ 且 $p \sim \text{Beta}(a, b)$, 观察到 $s = \sum_i Y_i$ 个成功后,

$$p | \mathbf{y} \sim \text{Beta}(a + s, b + n - s).$$

对 K 类计数 $(n_1, \dots, n_K)$, Dirichlet 先验 $\text{Dirichlet}(\alpha_1, \dots, \alpha_K)$ 相应更新为 $\text{Dirichlet}(\alpha_1 + n_1, \dots, \alpha_K + n_K)$ 。这些更新依赖给定比例后的条件独立抽样; 过度离散或来源相关时, 简单加计数会夸大信息量。

10.5.2 层次模型与部分汇聚

多个设备、标注者或任务的数据量很不均衡时, 可令

$$\theta_g \mid \mu, \tau^2 \sim \mathcal{N}(\mu, \tau^2), \quad Y_{g,i} \mid \theta_g \sim \mathcal{N}(\theta_g, \sigma_g^2).$$

这里假设给定 (μ, τ^2) 后各组参数 θ_g 条件独立, 并且给定全部组参数后, 所有 $Y_{g,i}$ 也条件独立。若 μ, τ^2, σ_g^2 暂视为已知, 且第 g 组有 n_g 个观测, 则

$$\theta_g \mid \mathbf{y}_g, \mu, \tau^2 \sim \mathcal{N}(m_g, V_g), \quad V_g^{-1} = \tau^{-2} + n_g \sigma_g^{-2},$$

$$m_g = V_g \left(\frac{\mu}{\tau^2} + \frac{n_g \bar{y}_g}{\sigma_g^2} \right).$$

固定超参数时, 第 g 组后验只依赖 $\mathbf{y}_g$ 以及外部给定的共同中心和尺度; 小样本群组会更强地向共同中心 μ 收缩, 其他组数据尚未进入该后验。当用全部群组数据估计共同超参数, 或在完整 Bayes 模型中对其后验积分时, 其他组数据才会通过共同超参数间接改变第 g 组的推断, 从而形成组间信息共享。 $\tau^2 \rightarrow 0$ 接近完全汇聚, $\tau^2 \rightarrow \infty$ 接近各组独立估计, 有限正尺度给出部分汇聚。若超参数由同一数据估计, 这是经验 Bayes; 若继续给它们指定先验, 推断对象还包括超参数后验。这不是免费增加数据, 而是加入“群组来自共同总体”的结构假设。若群组机制不同或先验尺度过窄, 收缩会掩盖真实差异。先验由研究者指定并不把固定物理参数变成随机生成的事实; Bayes 概率表达的是模型内部的不确定性。

10.6 区间、分位数与预测范围

10.6.1 置信、可信与预测区间

点估计没有说明误差尺度。**置信区间** (confidence interval) 是一项重复抽样程序: 若每次按同一制度抽样并构造 $C(\mathbf{Y})$, 则

$$\mathbb{P}_\theta \{\theta \in C(\mathbf{Y})\} \geq 1 - \alpha.$$

数据固定后, 频率学派参数不再随机, 不能把已经得到的区间解释为“以 $1 - \alpha$ 概率包含参数”。Bayes **可信区间** (credible interval) 则在给定数据和模型后满足 $\mathbb{P}(\theta \in C \mid \mathbf{y}) = 1 - \alpha$, 其数值依赖先验。**预测集合** (prediction set) 把覆盖对象改成未来结果, 在规定的训练样本与未来观测联合分布下要求 $\mathbb{P}\{Y_{n+1} \in C(\mathbf{Y})\} \geq 1 - \alpha$ 。三者的概率分别来自重复样本、参数后验

和未来观测，不能只按区间端点的外观解释。

高斯噪声且方差已知时，

$$\frac{\bar{Y} - \theta}{\sigma/\sqrt{n}} \sim \mathcal{N}(0, 1),$$

因而双侧置信区间为

$$\bar{Y} \pm z_{1-\alpha/2} \frac{\sigma}{\sqrt{n}}.$$

预测未来读数时，误差 $Y_{n+1} - \bar{Y}$ 的方差是 $\sigma^2(1 + 1/n)$ ，所以相同模型下的双侧预测区间为

$$\bar{Y} \pm z_{1-\alpha/2} \sigma \sqrt{1 + \frac{1}{n}}.$$

预测区间因此比参数区间更宽。参数区间覆盖固定位置参数，预测区间覆盖尚未发生的随机结果；把参数标准误直接用于预测会遗漏新观测噪声。

示例 10.5 贯穿本章的传感器校准数据 考虑一组教学构造的传感器校准数据。共有 $n = 25$ 个独立响应，样本均值为 $\bar{y} = 10.4$ ，已知单次测量噪声标准差为 $\sigma = 2$ ，样本经验二阶中心矩为

$$\frac{1}{25} \sum_{i=1}^{25} (y_i - \bar{y})^2 = 4.$$

在 95% 水平下， $z_{0.975} = 1.96$ 。位置参数的置信区间为

$$10.4 \pm 1.96 \frac{2}{5} = [9.62, 11.18],$$

而下一次读数的预测区间为

$$10.4 \pm 1.96 \times 2 \sqrt{1 + \frac{1}{25}} = [6.40, 14.40].$$

两个区间中心相同，宽度差异完全来自覆盖对象不同。

后文还要估计响应关于校准输入 x 的局部均值。靠近左边界 $x_0 = 0$ 的三个观测为

$$(x_i, y_i) = (0, 9), (1, 11), (3, 13),$$

在一个给定带宽下对应核权重 1, 0.75, 0.25。这些汇总量会在 Bootstrap、带宽选择和局部回归中继续使用；它们是用于复核方法差别的构造数值，不是实测性能报告。

方差未知时，用

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (Y_i - \bar{Y})^2$$

估计 σ^2 。高斯独立样本下,

$$\frac{\bar{Y} - \theta}{S/\sqrt{n}} \sim t_{n-1},$$

所以把高斯分位数换成 t 分位数可得到精确置信区间。这里的精确性依赖高斯性;一般分布下它通常只是渐近近似。样本很小且分布偏斜、重尾时,机械使用该区间可能同时破坏中心和尾部覆盖。

双侧区间与双侧检验在相同模型、显著性水平和统计量下互为反演:若 θ_0 不在 $1 - \alpha$ 置信区间内,就拒绝 $H_0: \theta = \theta_0$ 。这种对应关系要求两者使用相同标准误与尾部规则。选择后区间、单侧检验或离散检验中,不能只凭表面上的阈值照搬这一关系。

10.6.2 分位数、次序统计量与边际覆盖

q 分位数 (quantile) 可定义为

$$F^{-1}(q) = \inf\{y : F(y) \geq q\}, \quad 0 < q < 1.$$

这个广义逆为给定的 F 和 q 选出唯一的下分位数。更一般地,所有满足分位数不等式的点组成集合

$$\mathcal{Q}_q = \{a : F(a^-) \leq q \leq F(a)\}.$$

当 F 在水平 q 上存在平坦区间时,这个集合可能包含多个点;上述广义逆约定选取其中的下端代表。对次序统计量 $Y_{(1)} \leq \dots \leq Y_{(n)}$, 经验分位数由相应秩位置给出。若 $Y_1, \dots, Y_n$ 是来自连续分布 F 的独立同分布样本,则 $F(Y_{(k)})$ 服从 $\text{Beta}(k, n+1-k)$, 因此可以用秩而不是高斯近似构造分位数区间。对离散或混合分布,跳跃与平坦区间都要求覆盖计算保留定义中的不等式方向。

条件分位数可由**分位数回归** (quantile regression) 估计。令

$$\rho_q(u) = u(q - \mathbb{I}_{\{u < 0\}}),$$

则条件 q 分位数最小化 $\mathbb{E}[\rho_q(Y - a) | X = x]$ 。固定 x 并记条件分布函数为 F , 目标对 a 的次梯度区间是

$$[F(a^-) - q, F(a) - q].$$

因此最优点恰好满足 $F(a^-) \leq q \leq F(a)$; 连续严格递增时才简化为 $F(a) = q$ 。因此分位数损失的最小点集合正是 $\mathcal{Q}_q$, 可能不唯一, 而 $F^{-1}(q)$ 仍是其中按约定选出的单个代表。分位数回归直接估计条件分布的位置, 不要求误差为高斯或方差恒定。

第 8.12 节的共形预测用可交换观测的秩构造有限样本预测集。具体地,先用与校准集、待预测点分离的训练数据固定评分函数,再由 m 个校准分数 $S_1, \dots, S_m$ 取

$$k = \lceil (m+1)(1-\alpha) \rceil, \quad \hat{q} = S_{(k)}.$$

若 $k = m+1$, 约定阈值为 $+\infty$; 并列分数采用保守的“分数不超过阈值”规则。校准分数与新分数可交换时, 新分数的秩在 $m+1$ 个位置上对称, 因而分割共形的边际覆盖结论为

$$\mathbb{P}\{Y_{n+1} \in C(X_{n+1})\} \geq 1 - \alpha.$$

概率同时平均了不同 X 区域。它不推出每个群组或每个 x 都达到同样覆盖率; 分组校准只能对预先规定且样本充分的群组提供相应保证, 精细到每个连续条件点的无分布精确覆盖通常不可得。

10.7 假设检验与误差控制

10.7.1 检验、p 值与区间反演

区间描述目标的可能范围, **假设检验** (hypothesis testing) 则检查数据与一个命题是否相容。

定义 10.6 随机化检验函数 若单个观测的可测空间为 $\mathcal{Y}$, 则 **随机化检验函数** (randomized test function) 是可测映射

$$\varphi : \mathcal{Y}^n \rightarrow [0, 1].$$

观察到 $\mathbf{Y} = \mathbf{y}$ 后, 检验以概率 $\varphi(\mathbf{y})$ 拒绝原假设。等价地, 可另取独立的 $U \sim \text{Unif}(0, 1)$, 并在 $U \leq \varphi(\mathbf{y})$ 时拒绝。只取 0, 1 值的检验是非随机化特例, 其拒绝域为 $R = \{\mathbf{y} : \varphi(\mathbf{y}) = 1\}$ 。

原假设 H_0 指定被控制误报的情形。检验的大小与参数 θ 下的功效分别为

$$\sup_{\theta \in H_0} \mathbb{E}_\theta[\varphi(\mathbf{Y})], \quad \mathbb{E}_\theta[\varphi(\mathbf{Y})].$$

水平为 α 要求

$$\sup_{\theta \in H_0} \mathbb{E}_\theta[\varphi(\mathbf{Y})] \leq \alpha.$$

在 H_0 为真时拒绝是第一类错误; 在备择 H_1 为真时不拒绝是第二类错误。对非随机化检验, 这些期望分别退化为拒绝域概率。效应量描述差异有多大, 样本量则影响能否把该差异从噪声中区分出来。

p 值 (p -value) 是在原假设下, 得到至少与当前统计量同样极端结果的概率。更一般地, 一个随机变量 $p(\mathbf{Y})$ 是复合原假设下的有效 p 值, 若对每个 $u \in [0, 1]$ 都有

$$\sup_{\theta \in H_0} \mathbb{P}_\theta\{p(\mathbf{Y}) \leq u\} \leq u.$$

这项零假设下的超均匀性质才保证按阈值 α 拒绝时控制第一类错误。观察到的 p 值不是原假设为真的概率, 也不是效应量。仍取已知 σ 的高斯位置模型, 检验 $H_0: \theta = 0$ 时

$$Z = \frac{\sqrt{n}\bar{Y}}{\sigma}, \quad p = 2\{1 - \Phi(|Z|)\}.$$

若 $\theta = \delta$, 双侧检验功效为

$$\mathbb{P}_\delta(|Z| > z_{1-\alpha/2}) = 1 - \Phi\left(z_{1-\alpha/2} - \frac{\sqrt{n}\delta}{\sigma}\right) + \Phi\left(-z_{1-\alpha/2} - \frac{\sqrt{n}\delta}{\sigma}\right).$$

小样本下“不显著”可能只表示功效不足。相同效应量在更大 n 下会得到更小的 p 值。

检验族还可反演为置信集合。对每个候选值 θ_0 , 设 $\varphi_{\theta_0}(\mathbf{Y}) \in \{0, 1\}$ 是水平不超过 α 的检验, 并定义

$$C(\mathbf{Y}) = \{\theta_0 : \varphi_{\theta_0}(\mathbf{Y}) = 0\}.$$

当真实值为 θ 时,

$$\mathbb{P}_\theta\{\theta \notin C(\mathbf{Y})\} = \mathbb{P}_\theta\{\varphi_\theta(\mathbf{Y}) = 1\} \leq \alpha,$$

所以 C 具有至少 $1 - \alpha$ 覆盖率。这里必须对同一模型、同一尾部规则和同一标准误反演; 选择后换检验或只挑有利方向会破坏证明。

示例 10.7 同一效应量下的证据与功效 设噪声标准差已知为 $\sigma = 2$, 观测均值为 $\bar{y} = 1$, 检验 $H_0: \theta = 0$ 。当 $n = 4$ 时, $Z = 1$, 双侧 p 值约为 0.317; 当 $n = 100$ 时, $Z = 5$, 双侧 p 值小于 10^{-6} 。两次实验报告的标准化效应 $\bar{y}/\sigma = 0.5$ 相同, 证据强度却因标准误不同而变化。

若真实值确为 $\delta = 1$, 显著性水平为 0.05, 则 $n = 4$ 时双侧检验功效约为

$$1 - \Phi(1.96 - 1) + \Phi(-1.96 - 1) \approx 0.17.$$

此时未拒绝原假设并不支持“差异为零”。若实际问题把绝对差异不超过 0.2 视为等效, 还需要针对 $\Delta = 0.2$ 设计等效检验; 当前样本对这

个更严格目标几乎没有辨识度。

10.7.2 似然比排序与 Neyman-Pearson 引理

下面的经典引理给出两个简单假设之间的最强检验²。

定理 10.8 Neyman-Pearson 引理 对两个完全指定的简单假设 $H_0 : P = P_0$ 与 $H_1 : P = P_1$ ，设 $P_1 \ll P_0$ ，似然比为 $\Lambda = dP_1/dP_0$ 。在所有大小不超过 α 的检验中，拒绝大似然比并在边界适当随机化的检验具有最大功效。

² E. L. Lehmann, J. P. Romano, *Testing Statistical Hypotheses*, Springer, 2005, 3rd ed.

证明. 取常数 c 与边界随机化概率，使检验 φ^* 满足 $\mathbb{E}_0[\varphi^*] = \alpha$ ，并在 $\Lambda > c$ 时拒绝、在 $\Lambda < c$ 时接受。对任意 $\mathbb{E}_0[\varphi] \leq \alpha$ 的检验，

$$(\varphi^* - \varphi)(\Lambda - c) \geq 0$$

逐点成立，因为 φ^* 在 $\Lambda > c$ 处取最大允许值，在 $\Lambda < c$ 处取最小允许值。对 P_0 积分得到

$$\mathbb{E}_1[\varphi^* - \varphi] \geq c \mathbb{E}_0[\varphi^* - \varphi] \geq 0.$$

所以 φ^* 的备择拒绝概率不小于任何同大小检验。 ■

这个结论只直接覆盖两个简单假设。复合假设需要处理未知参数，不一定存在一致最强检验。在隐私攻击审计中， P_0 与 P_1 可分别表示目标记录不在与在训练集时的输出分布；似然比给出理想攻击排序，但实际审计还要估计这两个分布并计入选择偏差。

10.7.3 列联表、渐近检验与不同命题

两个分类变量的列联表中，原假设为独立时，期望格数是

$$E_{r,c} = \frac{N_{r\cdot} N_{\cdot c}}{N}, \quad X^2 = \sum_{r,c} \frac{(N_{r,c} - E_{r,c})^2}{E_{r,c}}.$$

在独立抽样、固定维数且期望格数不过小时， X^2 近似服从自由度 $(R - 1)(C - 1)$ 的卡方分布。稀疏格数会破坏近似，可合并有科学意义的类别或使用精确、置换方法。条件独立检验还要控制第三个变量；把样本简单切成大量小层会带来新的稀疏性，不能由普通卡方检验自动解决。

差异检验把“无差异”放在原假设中。等效性检验先给出有实际含义的可接受差异界 $\Delta > 0$ 。记 $\delta = \theta_A - \theta_B$ ，两个单侧检验 (two one-sided tests,

TOST) 把不等效原假设写成两个集合的并:

$$H_0 = H_{0,L} \cup H_{0,U}, \quad H_{0,L} : \delta \leq -\Delta, \quad H_{0,U} : \delta \geq \Delta.$$

对应备择为 $-\Delta < \delta < \Delta$ 。TOST 只有在水平 α 的下侧检验拒绝 $H_{0,L}$, 并且水平 α 的上侧检验也拒绝 $H_{0,U}$ 时, 才拒绝总体原假设。例如, 若 $\hat{\delta}$ 的标准误差为 s , 且标准化统计量服从相应正态近似, 拒绝条件为

$$\frac{\hat{\delta} + \Delta}{s} > z_{1-\alpha} \quad \text{且} \quad \frac{\hat{\delta} - \Delta}{s} < z_{\alpha}. \quad (10.3)$$

这等价于把双侧 $1 - 2\alpha$ 置信区间完整放入 $(-\Delta, \Delta)$ 。总体第一类错误并非 2α : 只要 $\delta \in H_0$, 至少有一个单侧原假设为真, 而总体拒绝事件包含在拒绝这个真原假设的事件中, 所以其概率至多为 α 。非劣效检验只排除一个方向, 例如 $H_0 : \delta \leq -\Delta$ 。未拒绝差异检验的零假设不等于证明等效。

10.8 重采样与经验不确定性

10.8.1 Bootstrap 与抽样分布近似

复杂估计量的抽样分布难以解析计算时, 可以让经验数据模拟重复抽样。**Bootstrap** 从经验分布 $\hat{P}_n = n^{-1} \sum_i \Delta_{Y_i}$ 有放回抽取 n 个观测, 并重新计算 $\hat{\tau}^*$ 。条件于原样本的 $\hat{\tau}^* - \hat{\tau}$ 近似 $\hat{\tau} - \tau(P)$ 的抽样波动。简单百分位区间取 Bootstrap 估计值的经验分位数, 但对不光滑统计量、边界参数、极端尾部分位数或重尾小样本, 近似可能很差。

对独立同分布、方差 $0 < \sigma^2 < \infty$ 的样本均值, 这个近似有清楚的缩放口径。若 $\bar{Y}^*$ 由经验分布条件重抽样, 则在原样本概率趋于一的意义下,

$$\mathcal{L}\left(\sqrt{n}(\bar{Y}^* - \bar{Y}) \mid Y\right) \Rightarrow \mathcal{N}(0, \sigma^2),$$

与 $\sqrt{n}(\bar{Y} - \mu)$ 的极限相同。理由是经验均值等于 $\bar{Y}$, 经验方差依概率趋于 σ^2 , 再对条件独立的重抽样应用中心极限定理。该结论针对中心化、缩放后的条件分布; 它本身不自动证明任意百分位区间具有高阶准确性。

例 10.5 中的经验分布均值为 10.4, 经验方差按分母 n 计算恰为 4。因此单次 Bootstrap 抽样值满足

$$\mathbb{E}_*[Y^*] = 10.4, \quad \text{Var}_*(Y^*) = 4,$$

而二十五次有放回抽样的均值满足

$$\text{SE}_*(\bar{Y}^*) = \sqrt{\frac{4}{25}} = 0.4.$$

若中心化并按标准误差标准化后的条件 Bootstrap 分布可由标准正态分布近

似，则正态 Bootstrap 区间为 $10.4 \pm 1.96 \times 0.4 = [9.62, 11.18]$ ，与已知方差高斯区间在这个构造例中重合。重合来自经验方差刚好等于已知噪声方差以及均值的光滑性，不是 Bootstrap 总会复制参数区间的保证。

这种近似可由平滑统计泛函的线性化理解。若

$$\hat{\tau} - \tau(P) = \frac{1}{n} \sum_{i=1}^n \text{IF}(Y_i; T, P) + o_{\mathbb{P}}(n^{-1/2}),$$

那么 Bootstrap 样本条件于原数据也产生相同形式的一阶平均，只是把 P 替换成 $\hat{P}_n$ 。因此两边经 $\sqrt{n}$ 缩放后的分布接近。样本最大值之类统计量没有这种常规线性展开：经验分布不会生成比当前最大值更大的观测，简单 Bootstrap 便可能错误描述尾部。

10.8.2 置换与交叉验证

置换检验 (permutation test) 近似的不是估计量抽样分布，而是零假设下标签可交换时的随机化分布。两组观测在“处理标签不影响联合分布”的原假设下，可反复打乱标签并重算组间差异。若分配机制只允许在区组内交换，就必须在区组内置换；任意全局打乱会制造实验中不可能出现的分配。

若允许的置换集合有 M 个元素，并把观测统计量与全部置换统计量一起排序，则交换对称性使真实排列的秩在这些位置上均匀；存在并列时使用

$$p_{\text{perm}} = \frac{\#\{\text{置换统计量不小于观测值}\}}{M}$$

得到超均匀而可能保守的 p 值。若只随机抽取 B 个置换，常用 $(1 + \#\{\text{抽样置换不小于观测值}\})/(B + 1)$ 保留有限模拟下的保守性。仅有两组均值相等并不保证整批标签可交换；交换性必须来自更强的零假设或随机分配设计。

交叉验证 (cross-validation) 把数据轮流分成训练部分和验证部分，估计“用同样训练流程在新数据上的预测误差”。它同时依赖训练规模、划分单位和调参流程。若用同一组折选择超参数又报告最优分数，结果仍含选择乐观偏差；需要嵌套交叉验证或独立测试集评估整个选择流程。

重采样单位必须跟独立单位一致。配对实验对整对数据重采样；多个记录属于同一用户时对用户群组重采样；时间相关数据使用保留局部依赖的块 Bootstrap。逐条重采样会把共享噪声误当作独立波动，通常低估标准误。

交叉验证各折的误差也不是彼此独立，因为训练集大量重叠。因此不能把 K 个折分数当成 K 个独立观测，再用普通样本方差构造过窄区间。若目标是比较两个算法，应在相同划分上计算配对差异，并把数据集抽样和

训练随机性纳入评价设计；单次 K 折结果主要用于误差估计与模型选择，不自动提供精确的显著性检验。

10.9 选择、多重比较与持续查看

10.9.1 多个假设与选中候选

单个检验的第一类错误为 α ，不代表同时尝试许多候选后仍只有 α 的误报概率。若 m 个原假设都为真，联合界给出

$$\mathbb{P}(\text{至少一次误拒绝}) \leq \sum_{j=1}^m \mathbb{P}(\text{拒绝 } H_j) \leq m\alpha.$$

Bonferroni 方法把每项阈值设为 α/m ，从而控制 **族错误率** (family-wise error rate, FWER)。它不要求检验独立，但候选很多时可能保守。

Holm 方法把 p 值从小到大排序，并依次将 $p_{(j)}$ 与 $\alpha/(m-j+1)$ 比较，遇到第一个未拒绝项即停止。若第一个被错误拒绝的真原假设位于位置 j ，设真原假设总数为 m_0 ，则前 $j-1$ 项均为假原假设，所以 $m-j+1 \geq m_0$ 。该真原假设的 p 值因而不超过 $\alpha/(m-j+1) \leq \alpha/m_0$ 。对全部 m_0 个真原假设应用联合界，便把发生任一错误拒绝的概率控制在 α 以内。它与 Bonferroni 一样不要求独立，但利用了逐步比较。

当目标是控制所有拒绝中错误发现的期望比例时，可使用 **错误发现率** (false discovery rate, FDR)。Benjamini-Hochberg 过程将 p 值排序为 $p_{(1)} \leq \dots \leq p_{(m)}$ ，找最大

$$k = \max \left\{ j : p_{(j)} \leq \frac{j}{m} q \right\},$$

并拒绝前 k 项。在独立或某些正相关条件下，它控制 FDR 不超过目标 q 。任意依赖下不能未经调整照搬这一结论。

从多个模型中挑选测试误差最小者，再把该最小值当成固定模型的无偏评估，会系统性偏乐观。候选越多，偶然低估越容易被选中。解决办法是把选择和最终评价分开，或把“选择算法”整体作为待评价对象。固定模型的区间不能在选择后继续冒充选中模型的区间。

例 10.5 还需要从两个预先给定的带宽中选择一个。用一个刻意简化、可精确计算的噪声模型说明选择偏差：假设两个带宽的真实预测均方误差都是 4，验证误差分别为

$$\hat{R}_j = 4 + \varepsilon_j, \quad \mathbb{P}(\varepsilon_j = 0.8) = \mathbb{P}(\varepsilon_j = -0.8) = \frac{1}{2}, \quad j = 1, 2,$$

并且两个误差独立。每个 $\hat{R}_j$ 单独都是无偏的，但两者最小值以概率 $1/4$

等于 4.8，以概率 $3/4$ 等于 3.2，所以

$$\mathbb{E} \min(\hat{R}_1, \hat{R}_2) = \frac{1}{4} \times 4.8 + \frac{3}{4} \times 3.2 = 3.6.$$

把选中带宽的 3.6 当作未来风险，平均会低估 0.4。嵌套交叉验证或独立测试集的作用，是评价“比较两个带宽再选择”这一完整流程，而不是重新评价已知固定的单个带宽。

10.9.2 持续查看与停止规则

持续查看同一数据也构成选择。固定时刻满足 $\mathbb{P}(p_t \leq \alpha) \leq \alpha$ 并不推出 $\mathbb{P}(\exists t : p_t \leq \alpha) \leq \alpha$ 。预先规定查看次数可分配 α 预算；更灵活的停止规则需要序贯检验、置信序列或由非负超鞅构造的 e 值。停止规则属于推断程序的一部分，不能在看到结果后删去。

置信序列 (confidence sequence) 是一列集合 $(C_t)_{t \geq 1}$ ，满足

$$\mathbb{P}_\theta \{\theta \in C_t \text{ 对所有 } t \geq 1\} \geq 1 - \alpha.$$

若 (E_t) 在原假设下是从 $E_0 = 1$ 开始的非负超鞅，则 Ville 不等式给出

$$\mathbb{P}_0 \left\{ \sup_{t \geq 0} E_t \geq \frac{1}{\alpha} \right\} \leq \alpha.$$

因此可以在任意由过去信息决定的停止时刻按阈值查看 E_t ，而不增加这项越界概率。这不表示停止后的点估计无偏，也不表示同时尝试多个证据过程无需额外控制；覆盖、估计偏差和模型选择证据仍是不同问题。

10.10 概率预测、评分与校准

10.10.1 适当评分与最优预测分布

点预测只给一个结果，概率预测则给出整个候选分布。评价它需要 **评分规则** (scoring rule) $S(Q, y)$ ，即报告预测分布 Q 而结果为 y 时承担的损失。若真实分布为 P 时，报告 $Q = P$ 使期望损失最小，就称评分规则 **适当** (proper)；若适用分布类中的最小点唯一，则称为严格适当。它奖励诚实概率，而不是只检查最可能类别是否猜中。

先考虑有限结果集 $\mathcal{Y}$ ，并记 P, Q 的概率质量函数为 p, q 。本节只需有限离散情形的 **KL 散度** (Kullback–Leibler divergence)：

$$D_{\text{KL}}(P \| Q) = \sum_{y \in \mathcal{Y}} p(y) \log \frac{p(y)}{q(y)}.$$

其中约定 $0 \log(0/q) = 0$ ；只要存在 $p(y) > 0$ 而 $q(y) = 0$ ，就令散度为 $+\infty$ 。

由 $-\log u \geq 1 - u$ 可得 $D_{\text{KL}}(P||Q) \geq 0$, 等号当且仅当 $P = Q$ 。这也可看成对凸函数 $-\log$ 应用 Jensen 不等式: 在 P 的支持上平均 $q(y)/p(y)$, 所得总和不超过 1。第 11 章将在一般测度空间上定义这一量, 并系统讨论其性质。

离散结果的对数评分为 $S(Q, y) = -\log q(y)$ 。根据上述定义, 其期望差满足

$$\mathbb{E}_P[S(Q, Y)] - \mathbb{E}_P[S(P, Y)] = \sum_{y \in \mathcal{Y}} p(y) \log \frac{p(y)}{q(y)} = D_{\text{KL}}(P||Q) \geq 0.$$

因此对数评分是严格适当的; 零预测概率遗漏真实分布的支持时, 期望损失为无穷。连续密度版本还要求相对于共同参考测度定义密度, 并保证相关对数期望有定义; 改变参考坐标会改变单个对数密度值, 但在合法换元下比较同一结果分布的期望差保持一致。

二元结果 $Y \in \{0, 1\}$ 的 Brier 评分为 $S(q, Y) = (q - Y)^2$ 。若真实事件概率为 p , 则

$$\mathbb{E}_p[(q - Y)^2] = p(q - 1)^2 + (1 - p)q^2 \quad (10.4)$$

$$= (q - p)^2 + p(1 - p). \quad (10.5)$$

第二项与报告 q 无关, 所以唯一最优报告是 $q = p$ 。对数评分更强烈惩罚对已发生事件给极小概率, Brier 评分则有界; 两者表达不同风险偏好。

对 K 个类别, 令真实概率向量为 $\mathbf{p}$, 报告为 $\mathbf{q}$, Brier 评分可写成 $S(\mathbf{q}, Y) = \sum_{k=1}^K (q_k - \mathbb{I}\{Y = k\})^2$ 。直接展开得到

$$\mathbb{E}_{\mathbf{p}}[S(\mathbf{q}, Y)] = \|\mathbf{q} - \mathbf{p}\|_2^2 + 1 - \|\mathbf{p}\|_2^2.$$

所以它在概率单纯形上同样严格适当, 但控制的是概率向量的平方距离, 不是对数密度比。

10.10.2 校准、区分能力与锐度

校准 (calibration) 要求预测概率相同的样本具有相应发生率, 例如理想情况下 $\mathbb{P}(Y = 1 \mid \hat{p} = p) = p$ 。**区分能力** (discrimination) 描述模型能否给更可能发生事件的样本更高分; **锐度** (sharpness) 描述预测分布是否集中。对所有样本恒报基准发生率可以完美校准, 却没有区分能力。锐度只有在校准前提下才值得追求。

令 $Q = \hat{p}(X)$, $\eta(Q) = \mathbb{E}[Y \mid Q]$, 再记总体发生率为 $\bar{p} = \mathbb{E}[Y]$ 。条件平

方展开给出

$$\mathbb{E}[(Q - Y)^2] = \underbrace{\mathbb{E}[(Q - \eta(Q))^2]}_{\text{校准误差}} + \underbrace{\bar{p}(1 - \bar{p}) - \text{Var}(\eta(Q))}_{\text{剩余不可分辨误差}}.$$

第一项为零才表示相对于预测值本身校准；第二项随不同预测组的真实风险更可区分而减小。恒报 $\bar{p}$ 使第一项为零，却也使 $\text{Var}(\eta(Q)) = 0$ 。多类别校准相应要求 $\mathbb{P}(Y = k \mid \hat{\mathbf{p}}) = \hat{p}_k$ 对每个类别成立，逐类别边际校准通常弱于这个向量条件。

10.10.3 后处理校准与评价条件

温度缩放对分类 logit $\mathbf{z}$ 使用 $\text{softmax}(\mathbf{z}/T)$ ，在校准集上按对数损失估计 $T > 0$ 。它保持类别排序，只调整置信程度。保序回归则拟合单调的分数到概率映射，更灵活但更容易在小校准集上过拟合。给定排序分数 s_i ，其典型拟合问题是在 $q_1 \leq \dots \leq q_m$ 约束下最小化 $\sum_i (q_i - y_i)^2$ ；单调约束不等于总体校准保证。训练原预测器、拟合校准器和评价校准效果应使用职责分离的数据或严格的折外预测；部署总体若发生变化，旧映射也未必保持校准。分箱可靠性图只是把连续条件近似成有限组，箱内比例仍有抽样误差，且结果依赖分箱边界。适当评分、边际覆盖和校准分别评价分布损失、未来集合与条件发生率，不能互相替代。

10.11 非参数估计与不完整观测

10.11.1 密度估计与带宽

有限维模型可能把真实分布限制得过强。非参数方法不预先固定有限个参数，但仍通过带宽、邻域或平滑度控制复杂度。给定宽度为 h 的分箱，直方图用“箱内样本数除以 nh ”作为箱内常数密度；移动箱边界可能改变估计。核密度估计则把每个样本扩散为核：

$$\hat{f}_h(x) = \frac{1}{nh} \sum_{i=1}^n K\left(\frac{x - Y_i}{h}\right).$$

若 $K \geq 0$ 、积分为 1，则 $\hat{f}_h$ 本身是非负且积分为 1 的密度。进一步假设 K 对称、二阶矩 $\mu_2(K)$ 与 $R(K) = \int K(u)^2 du$ 有限，且 f 在内部点 x 附近二阶光滑，则由

$$\mathbb{E}[\hat{f}_h(x)] = \int K(u)f(x - hu) du$$

作 Taylor 展开，核的一阶矩因对称性消失，从而得到

$$\text{Bias}\{\hat{f}_h(x)\} = \frac{h^2 \mu_2(K)}{2} f''(x) + o(h^2),$$

$$\text{Var}\{\hat{f}_h(x)\} = \frac{f(x)R(K)}{nh} + o((nh)^{-1}),$$

其中渐近式取 $h \rightarrow 0$ 、 $nh \rightarrow \infty$ 。较大带宽降低方差却增加平滑偏差。边界附近因核质量落到支持集外，上述对称展开失效。在 d 维中，体积因子变为 h^d ，代表性点态方差阶数相应为 $1/(nh^d)$ 。因此维数增加会更快消耗局部样本；一维的带宽结论不能不改条件直接移植到高维。

10.11.2 局部预测与近邻

回归函数 $m(x) = \mathbb{E}[Y | X = x]$ 可由局部平均估计：

$$\hat{m}_h(x) = \frac{\sum_i K((X_i - x)/h)Y_i}{\sum_i K((X_i - x)/h)}.$$

局部线性回归在 x 附近拟合 $a + b(X_i - x)$ ，能减轻设计密度不均和边界偏差。

$$(\hat{a}, \hat{b}) \in \arg \min_{a,b} \sum_{i=1}^n K\left(\frac{X_i - x}{h}\right) \{Y_i - a - b(X_i - x)\}^2, \quad \hat{m}_{\text{local}}(x) = \hat{a}.$$

k 近邻则用离 x 最近的 k 个样本平均。维数增大时，为包含足够邻居必须扩大邻域，Taylor 局部性随之变差，这就是维数灾难的一种表现。

在例 10.5 的左边界 $x_0 = 0$ ，局部常数估计为

$$\hat{m}_h(0) = \frac{1 \times 9 + 0.75 \times 11 + 0.25 \times 13}{1 + 0.75 + 0.25} = 10.25.$$

局部线性拟合令 $u_i = x_i - x_0$ 。由这三个点可算得

$$S_0 = \sum_i w_i = 2, \quad S_1 = \sum_i w_i u_i = 1.5, \quad S_2 = \sum_i w_i u_i^2 = 3,$$

$$T_0 = \sum_i w_i y_i = 20.5, \quad T_1 = \sum_i w_i u_i y_i = 18.$$

加权正规方程给出

$$\hat{a} = \frac{S_2 T_0 - S_1 T_1}{S_0 S_2 - S_1^2} = 9.2, \quad \hat{b} = \frac{S_0 T_1 - S_1 T_0}{S_0 S_2 - S_1^2} = 1.4.$$

因此局部线性预测为 9.2，而局部常数预测为 10.25。在边界处，后者只能对单侧观测加权平均，前者还估计局部斜率并把直线截距放回 x_0 ；哪一个更接近真实条件均值仍取决于局部线性近似和带宽是否合适，不能由这一组数值单独决定。

这些方法的一致性需要邻域既缩小又包含越来越多样本。例如一维内部点处，若输入密度在 x 附近连续且为正，条件均值足够光滑，条件方差局部有界，并取 $h \rightarrow 0$ 、 $nh \rightarrow \infty$ ，局部常数估计的平滑偏差消失，局部平

均的方差也消失。二阶光滑时其典型平方偏差为 $O(h^4)$, 方差为 $O((nh)^{-1})$, 但精确常数还依赖核、输入密度与条件噪声。近邻版本相应要求 $k \rightarrow \infty$ 且 $k/n \rightarrow 0$ 。这些都是目标分布有局部覆盖时的内插结论；在训练输入密度为零的区域，缩小邻域无法产生新信息，外推保证必须来自额外结构假设。

10.11.3 缺失、选择与可忽略性

不完整观测带来另一类问题。令 $R = 1$ 表示 Y 被观察到, X 为始终可见变量。**完全随机缺失** (missing completely at random, MCAR) 要求

$$R \perp (X, Y).$$

随机缺失 (missing at random, MAR) 要求

$$R \perp Y \mid X,$$

即给定已观测协变量后, 缺失概率不再依赖缺失值本身。**非随机缺失** (missing not at random, MNAR) 则允许这种剩余依赖。

当 $\mathbb{P}(R = 1) > 0$ 时, MCAR 下完整案例仍代表总体, 但效率降低。MAR 下可建模 $\mathbb{P}(R = 1 \mid X)$ 并加权, 或建模 $Y \mid X$ 后插补; 两者都依赖模型和正值条件。MNAR 通常不能只靠已观测数据识别, 需要机制假设、外部信息或敏感性分析。所谓“缺失机制可忽略”还要求推断参数与缺失机制参数可分离; Bayes 分析中还涉及先验可分离。数据表中的一个缺失标记本身不能证明属于哪种机制。

识别障碍在有界结果上已经出现。若 $0 \leq Y \leq 1$ 且 $\mathbb{P}(R = 0) > 0$, 观测数据只给出已见部分的 RY 与缺失指示; 把所有未见 Y 设为 0 或设为 1 会产生相同观测, 却给出不同总体均值。因此不加机制条件时只能得到

$$\mathbb{E}[RY] \leq \mathbb{E}[Y] \leq \mathbb{E}[RY] + \mathbb{P}(R = 0).$$

两个端点分别可由把全部未见结果设为 0 或 1 达到, 所以仅凭上述信息不能继续收紧。若 MAR 成立, 并令 $\pi(X) = \mathbb{P}(R = 1 \mid X) > 0$, 则第 10.2 节的逆概率恒等式在这里化为

$$\mathbb{E}\left[\frac{RY}{\pi(X)}\right] = \mathbb{E}[Y].$$

正值条件负责覆盖, 条件独立负责把未见结果接回已见结果; 权重很大时, 即使目标可识别, 有限样本方差仍可能很高。

10.12 模型证据与局部积分近似

10.12.1 预测、似然与边缘似然

模型选择准则并非都在回答同一问题。独立测试误差比较未来预测；训练似然衡量已观测数据在拟合参数下的密度；边缘似然

$$p(\mathbf{y} | M) = \int p(\mathbf{y} | \vartheta, M) \pi(\vartheta | M) d\vartheta$$

对参数不确定性积分；编码长度则把模型和数据的描述代价相加。一个模型可能训练似然高，却因复杂度、先验体积或泛化误差而不被其他准则选择。

两个模型 M_1, M_0 的 **Bayes 因子** (Bayes factor) 是

$$\text{BF}_{1,0} = \frac{p(\mathbf{y} | M_1)}{p(\mathbf{y} | M_0)}.$$

它要求两个边缘似然都由适当先验得到且分母正而有限。Bayes 因子更新的是模型间先验赔率，不是与先验无关的“模型为真概率”。在高斯位置模型中，若 $\theta \sim \mathcal{N}(0, A^2)$ ，则 $\bar{Y} \sim \mathcal{N}(0, A^2 + \sigma^2/n)$ 。保持似然峰值不变而增大 A 会把先验质量摊到更宽区域；对固定 $\bar{y}$ ，当 $A \rightarrow \infty$ 时该边缘密度趋于零。这正是模型证据依赖参数先验尺度的一个可复核例子。

10.12.2 Laplace 近似与 BIC

定理 10.9 固定维 Laplace 局部积分近似 设 $\Theta \subseteq \mathbb{R}^d$ 为可测集， $\hat{\vartheta} \in \text{int}(\Theta)$ 。函数 $h : \Theta \rightarrow \mathbb{R}$ 可测，并在 $\hat{\vartheta}$ 的某个邻域内二阶连续可微；该点是 h 在 Θ 上的唯一全局最大点，且 $\mathbf{H} = -\nabla^2 h(\hat{\vartheta})$ 正定。函数 $g : \Theta \rightarrow [0, \infty)$ 局部可积，在该点的某个邻域内连续，并满足 $g(\hat{\vartheta}) > 0$ 。

进一步假设存在 $\delta, \eta > 0$ 和 $n_0 \geq 1$ ，使 $\overline{B_\delta(\hat{\vartheta})} \subseteq \Theta$ ， h, g 在该闭球所在的邻域内分别满足上述光滑性与连续性，并且

$$\sup_{\vartheta \in \Theta \setminus B_\delta(\hat{\vartheta})} h(\vartheta) \leq h(\hat{\vartheta}) - \eta, \quad \int_{\Theta} \exp\{n_0[h(\vartheta) - h(\hat{\vartheta})]\} g(\vartheta) d\vartheta < \infty.$$

则当 $n \rightarrow \infty$ 时，

$$\int_{\Theta} \exp\{nh(\vartheta)\} g(\vartheta) d\vartheta = \exp\{nh(\hat{\vartheta})\} g(\hat{\vartheta}) \left(\frac{2\pi}{n}\right)^{d/2} |\mathbf{H}|^{-1/2} \{1 + o(1)\}.$$

证明. 正定性与二阶连续性保证：必要时缩小 δ ，存在 $c > 0$ ，使闭球内有

$$h(\vartheta) - h(\hat{\vartheta}) \leq -c \|\vartheta - \hat{\vartheta}\|_2^2.$$

缩小闭球后, 原闭球中剩余的紧致环带由唯一最大性给出严格间隔; 把它与原来的尾部间隔合并, 仍可取某个 $\eta > 0$ 满足定理中的一致上界。另一方面, 在最大点附近作多元 Taylor 展开:

$$h(\boldsymbol{\vartheta}) = h(\hat{\boldsymbol{\vartheta}}) - \frac{1}{2}(\boldsymbol{\vartheta} - \hat{\boldsymbol{\vartheta}})^\top \mathbf{H}(\boldsymbol{\vartheta} - \hat{\boldsymbol{\vartheta}}) + o(\|\boldsymbol{\vartheta} - \hat{\boldsymbol{\vartheta}}\|_2^2).$$

令 $\mathbf{u} = \sqrt{n} \mathbf{H}^{1/2}(\boldsymbol{\vartheta} - \hat{\boldsymbol{\vartheta}})$, 则逆变换的 Jacobian 行列式绝对值为 $n^{-d/2} |\mathbf{H}|^{-1/2}$, 即 $d\boldsymbol{\vartheta} = n^{-d/2} |\mathbf{H}|^{-1/2} d\mathbf{u}$ 。对每个固定的 $\mathbf{u}$, Taylor 展开与 g 的连续性使变换后的被积函数收敛到 $g(\hat{\boldsymbol{\vartheta}}) \exp(-\|\mathbf{u}\|_2^2/2)$ 。局部二次上界和 g 在闭球上的有界性给出可积的高斯控制函数, 因此支配收敛定理给出

$$\int_{B_\delta(\hat{\boldsymbol{\vartheta}})} \exp\{n[h(\boldsymbol{\vartheta}) - h(\hat{\boldsymbol{\vartheta}})]\} g(\boldsymbol{\vartheta}) d\boldsymbol{\vartheta} = n^{-d/2} |\mathbf{H}|^{-1/2} g(\hat{\boldsymbol{\vartheta}}) (2\pi)^{d/2} \{1 + o(1)\}.$$

闭球外的尾项满足

$$\int_{\Theta \setminus B_\delta(\hat{\boldsymbol{\vartheta}})} e^{n[h(\boldsymbol{\vartheta}) - h(\hat{\boldsymbol{\vartheta}})]} g(\boldsymbol{\vartheta}) d\boldsymbol{\vartheta} \leq e^{-(n-n_0)\eta} \int_{\Theta} e^{n_0[h(\boldsymbol{\vartheta}) - h(\hat{\boldsymbol{\vartheta}})]} g(\boldsymbol{\vartheta}) d\boldsymbol{\vartheta} = o(n^{-d/2}).$$

局部主项与该尾项相加即得结论。 ■

上一定理描述固定函数 h 的基本形式。在正则独立样本模型中, 实际处理的是随机函数序列

$$nh_n(\boldsymbol{\vartheta}) = \ell_n(\boldsymbol{\vartheta}) = \sum_{i=1}^n \log p_{\boldsymbol{\vartheta}}(y_i), \quad g(\boldsymbol{\vartheta}) = \pi(\boldsymbol{\vartheta}).$$

若极大似然估计以内点唯一最大点的形式收敛, 归一化观测信息矩阵收敛到正定极限, 先验在极限点附近连续且为正, 并且局部二次展开与尾部控制对该序列一致成立, 则相同论证给出

$$\log p(\mathbf{y} | M) = \ell_n(\hat{\boldsymbol{\vartheta}}) - \frac{d}{2} \log n + O_{\mathbb{P}}(1).$$

对固定的有限候选模型集合, 乘以 -2 并只保留随 n 发散的项, 得到常用形式

$$\text{BIC} = -2\ell_n(\hat{\boldsymbol{\vartheta}}) + d \log n.$$

惩罚来自后验高密度区域体积随 $n^{-d/2}$ 缩小, 而不是人为给参数个数加价。

10.12.3 AIC、描述长度与比较口径

在独立、固定维且正则的最大似然设定中, 常用

$$\text{AIC} = -2\ell_n(\hat{\boldsymbol{\vartheta}}) + 2d.$$

其中 $2d$ 是一阶校正拟合对预期样本外对数损失的乐观偏差，目标是预测失配；模型失配时还要核对适用的协方差校正，不能只数参数。BIC 近似特定先验下的边缘似然，常以候选中存在真模型的正则渐近为背景。**最小描述长度**（minimum description length, MDL）则先规定可解码的模型代码与给定模型后的数据代码，再最小化二者总长度；更换编码对象或精度约定会改变有限样本准则。三者惩罚形式相似时也不能互换解释，更不能共享未经证明的选择一致性。

混合模型的标签交换、参数位于边界、额外成分权重为零或 Fisher 信息奇异时，最大点可能不唯一，局部曲率可能退化，常规 Laplace 展开和 $d \log n$ 惩罚随之失效。此时应使用适合奇异模型的方法、数值积分或明确的近似；近似边缘似然不能写成精确证据。

10.13 对照、预算与信息获取

10.13.1 随机分配与可复核对照

推断质量不仅由分析方法决定，也由数据如何取得决定。每个对象在各处理下本会产生结果称为潜在结果，正式的因果目标将在第 12 章定义。随机分配使处理指派在设计上独立于这些预先固定的结果，从而把系统差异转成可量化的随机误差。配对对照先按对象或关键协变量配对，再在对内比较，可消除共享噪声。若配对质量差或分析时忽略配对，预期的方差收益不会自动出现。

先看最简单的两组位置模型。若随机分配后两组分别有 n_A, n_B 个独立观测，均值为 μ_A, μ_B ，方差为 σ_A^2, σ_B^2 ，则

$$\hat{\Delta} = \bar{Y}_A - \bar{Y}_B, \quad \mathbb{E}[\hat{\Delta}] = \mu_A - \mu_B,$$

$$\text{Var}(\hat{\Delta}) = \frac{\sigma_A^2}{n_A} + \frac{\sigma_B^2}{n_B}.$$

随机化建立的是处理指派与处理前对象特征之间的概率关系，并不要求两种处理下的结果服从同一分布。上式还假设组间独立且组内方差有限；配对随机化应改为分析对内差值。它提供的是设计下的可复核比较，潜在结果目标及从试验人群向目标总体的推广条件由第 12 章继续建立。

消融实验删除一个组件并保持其他条件不变，用来判断该组件对整体结果的增量贡献。它不能在组件强交互时给出唯一的“独立贡献”，也不能用不同训练预算的两个系统冒充单因素比较。基线、随机种子、停止规则和评价集都应在比较前固定。

学习曲线把训练样本量或计算量与验证性能联系起来。只报告最终点无法区分方法是数据效率更高，还是只是使用了更多数据和算力。实验至少要区分数据预算、计算预算与评价时间预算：收集更多标签、搜索更多

配置和反复占用测试集是三种不同资源。

10.13.2 预算下的精度与信息价值

预算分配应对应希望降低的误差。若两组单位观测成本相同且 $n_A + n_B = N$ ，最小化上面的均值差方差可得

$$\frac{n_A}{n_B} = \frac{\sigma_A}{\sigma_B}.$$

这是对 n_A 求导或用 Cauchy-Schwarz 得到的 Neyman 分配：波动较大的组需要更多观测。方差未知时要用先验信息或先导样本估计，估计误差也应计入设计；整数、最低组规模 and 不同成本会改变解。

线性观测模型 $\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$ 提供了多方向设计的接口，其中 $\mathbf{X} \in \mathbb{R}^{n \times d}$ 、 $\boldsymbol{\beta}, \mathbf{a} \in \mathbb{R}^d$ 。给定满列秩设计矩阵 $\mathbf{X}$ ，假设 $\mathbb{E}[\boldsymbol{\varepsilon} | \mathbf{X}] = \mathbf{0}$ 且 $\text{Cov}(\boldsymbol{\varepsilon} | \mathbf{X}) = \sigma^2 \mathbf{I}_n$ 。普通最小二乘估计量为

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}.$$

它在给定 $\mathbf{X}$ 时无偏，并且

$$\text{Var}(\mathbf{a}^\top \hat{\boldsymbol{\beta}} | \mathbf{X}) = \sigma^2 \mathbf{a}^\top (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{a}.$$

因此新增观测的特征方向会改变设计矩阵，并降低某些 $\mathbf{a}$ 方向的方差；它未必同样改善其他方向、预测总体或非线性目标。最小化最坏方向、平均方向或行列式体积会得到不同设计准则，必须先声明评价对象。

当标注预算有限时，**主动学习**（active learning）根据当前模型选择下一批待标注样本。若效用 U 已经包含任务收益与查询成本，一个理想选择可写成最大化期望效用增量：

$$\mathbf{x}^* \in \arg \max_x \mathbb{E}_{Y|x, \mathcal{D}} [U(\mathcal{D} \cup \{(x, Y)\}) - U(\mathcal{D})],$$

其中 U 衡量后验不确定性减少或决策效用增加。只选当前最不确定样本是一种替代规则，不一定等于任务价值最大。若 U 取熵下降，才与第 11 章的互信息接口相连；若 U 取行动后的最优风险，则接到第 17.4 节的信息价值。信息量增加与任务效用增加不是同一命题。

主动选择会改变被标注样本的分布。若候选池不覆盖目标总体，算法无法询问缺失区域；若标注噪声随难度变化，不确定样本还可能最不可靠；若最终指标用同一批自适应选择数据计算，评价也会偏移。因此应在比较前固定可访问数据、查询成本、标注机制和独立评价集。查询依赖过去答案时，所选特征或对象必须在新噪声揭示前由历史信息确定，才能回用第 9 章的可预测设计与自适应误差工具；把自适应记录事后当作固定独立

样本没有同样保证。实验设计不是分析完成后的附注，而是可识别性和误差保证的一部分。

10.14 本章小结

带噪观测不能单靠样本量变成可靠结论。统计推断先确定目标总体和抽样单位，再检查未知目标能否由观测分布识别。似然、矩条件和稳健准则提供不同的估计途径；偏差、方差、Fisher 信息与渐近分布说明它们在正则条件下能达到什么精度。Bayes 更新把先验假设纳入同一计算，并通过后验预测保留参数与未来噪声两层不确定性。

点估计、置信区间、可信区间、预测区间和检验各有不同的随机对象，不能因数值形式相近而混用。重采样必须尊重独立单位，多重选择和持续查看必须进入误差控制。概率评分评价整个预测分布，校准、区分能力与锐度分别检查不同性质；非参数平滑和缺失数据方法则把模型限制与观测机制显式化。

模型证据依赖选择目标和正则条件，Laplace 近似、BIC、AIC 与编码长度不提供无条件一致的答案。最终，随机对照、预算安排和主动获取决定了数据中能够出现什么信息。第 11 章将从信息量与可区分性研究推断的根本限制，第 12 章则在干预目标下重新检查“观测到的关联能否识别行动效果”。

信息论与统计几何

概率论给出了分布、条件化和换测度的语言，数理统计则把未知分布或参数作为推断对象。不过，仅仅知道两个模型的参数相差多少，还不能判断观测能否区分它们。对 $\mathcal{N}(0, 1)$ 与 $\mathcal{N}(0.1, 1)$ ，均值差、对数似然差、事件概率差和搬运质量所需的距离都可以计算，但它们回答的是不同问题；若把均值重新参数化为其立方根，参数的欧氏距离还会随坐标改变。本章研究怎样从分布本身比较不确定性、可区分性与局部变化。编码长度引出熵，预测分布的对数损失引出相对熵；事件、测试函数和搬运成本又给出不同的分布差异。换测度的指数矩不等式把这些差异接到学习保证，Le Cam 与 Fano 方法则把“分布太相近”转成任何估计器都无法越过的误差下界。在几何一侧，Wasserstein 距离从质量搬运刻画全局位置变化，Fisher 度量从 KL 的二阶项刻画参数模型的局部几何，变分表达把推断与分布优化连接起来。除非另有说明，本章使用自然对数，信息量的单位为 nat。若改用以 2 为底的对数，信息量单位为 bit，所有数值只相差常数因子。第 8 章已经建立 Radon-Nikodym 导数、条件分布与指数族；本章在使用这些对象时仍逐项核对绝对连续、可积性和正则性。

11.1 不确定性与熵

11.1.1 平均编码长度为何出现对数

设离散随机变量 X 取值于有限或可数字母表 $\mathcal{X}$ ，质量函数为 $p(x)$ 。若使用二进制前缀码，结果 x 的码长记为 $\ell(x)$ 。前缀码的码字不能是另一码字的前缀，因而码长必须满足 Kraft 不等式

$$\sum_{x \in \mathcal{X}} 2^{-\ell(x)} \leq 1.$$

概率较大的结果应分配较短码字，但码长不能彼此独立地任意缩短。理想实数码长 $-\log_2 p(x)$ 恰好满足等号，因为 $\sum_x p(x) = 1$ 。

定义 11.1 离散熵 若 $\sum_x p(x) |\log p(x)| < \infty$, 则 X 的熵 (entropy) 定义为

$$H(X) = - \sum_{x \in \mathcal{X}} p(x) \log p(x) = \mathbb{E}[-\log p(X)], \quad (11.1)$$

其中约定 $0 \log 0 = 0$ 。

熵是按真实发生频率加权的理想描述长度。它不是某次结果携带的信息, 而是结果发生前的平均不确定性。若 X 几乎必然为常数, 则 $H(X) = 0$; 若 X 在 m 个结果上均匀分布, 则 $H(X) = \log m$ ¹。例如, 若 $X \sim \text{Bernoulli}(1/4)$, 则

$$H(X) = -\frac{1}{4} \log \frac{1}{4} - \frac{3}{4} \log \frac{3}{4} \approx 0.5623 \text{ nat} \approx 0.8113 \text{ bit}.$$

二元前缀码必须给两个结果各分配至少一位, 所以其逐符号平均码长为 1 bit; 熵给出理想实数码长的平均值, 二者的差来自整数码长约束。

¹ T. M. Cover, J. A. Thomas, *Elements of Information Theory*, Wiley, 2006, 2nd ed.

定理 11.2 无失真前缀码的平均长度界 对熵有限的质量函数 p 和任意满足 Kraft 不等式的二进制码长 $\ell(x)$, 有

$$\mathbb{E}[\ell(X)] \geq H(X) / \log 2.$$

反过来, 在有效字母表 $\mathcal{X}_+ = \{x : p(x) > 0\}$ 上取 $\ell(x) = \lceil -\log_2 p(x) \rceil$, 可构造前缀码, 并满足

$$\mathbb{E}[\ell(X)] < H(X) / \log 2 + 1.$$

证明. 令 $K = \sum_x 2^{-\ell(x)} \leq 1$, 并在 $K > 0$ 时定义 $q(x) = 2^{-\ell(x)}/K$ 。由 $-\log u \geq 1 - u$, $\sum_x p(x) \log[p(x)/q(x)] \geq 1 - \sum_{x: p(x) > 0} q(x) \geq 0$, 因此

$$0 \leq \sum_x p(x) \log \frac{p(x)}{q(x)} = -H(X) + (\log 2) \mathbb{E}[\ell(X)] + \log K.$$

由于 $\log K \leq 0$, 移项便得到下界。对取整码长, $2^{-\ell(x)} \leq p(x)$, 故 Kraft 不等式成立。为看清逆向构造, 按码长从短到长排列 $\mathcal{X}_+$, 依次在 $[0, 1)$ 中放置长度为 $2^{-\ell(x)}$ 且端点与该层二进网格对齐的区间; Kraft 不等式保证所有区间都能放下。用每个区间左端点的前 $\ell(x)$ 个二进制位作为码字。两个这样的二进区间若相交, 较短码字必为较长码字的前缀; 构造中的区间互不相交, 所以所得码是前缀码。这就是 Kraft-McMillan 逆向构造。又因 $\lfloor a \rfloor < a + 1$, 对 $p(x) > 0$ 逐项平均即得上界。满足 $p(x) = 0$ 的符号不会由信源产生, 对熵和平均码长均无贡献, 因而从有效字母表中删除; 若应用要求传输这些符号, 必须另外为它们保留码空间, 相应冗余不由上述小于一位的界保证。 ■

这个结论只讨论无失真、逐符号可唯一解析的编码。允许块编码时，每个符号的整数取整代价可以趋近于零；允许失真时，最优码长还取决于失真准则，不能只由 $H(X)$ 决定。

11.1.2 条件熵与链式法则

对离散随机变量 X, Y ，给定 $Y = y$ 后仍需描述 X 的平均长度为

$$H(X | Y = y) = - \sum_x p(x | y) \log p(x | y).$$

再对 Y 平均，得到**条件熵**（conditional entropy）

$$H(X | Y) = - \sum_{x,y} p(x, y) \log p(x | y). \quad (11.2)$$

它衡量已经知道 Y 以后， X 还剩多少不确定性。对可数字母表，这个定义允许取值 $+\infty$ 。以下推导假设 $H(X, Y) < \infty$ ，从而出现的边缘熵与条件熵均为有限值。此时联合质量分解为 $p(x, y) = p(y)p(x | y)$ ，所以

$$\begin{aligned} H(X, Y) &= - \sum_{x,y} p(x, y) \log p(x, y) \\ &= - \sum_{x,y} p(x, y) \log p(y) - \sum_{x,y} p(x, y) \log p(x | y) \\ &= H(Y) + H(X | Y). \end{aligned}$$

这就是熵的链式法则。反复使用可得

$$H(X_1, \dots, X_n) = \sum_{i=1}^n H(X_i | X_1, \dots, X_{i-1}). \quad (11.3)$$

其中假设 $H(X_1, \dots, X_n) < \infty$ 。链式法则是同一联合分布的不同分解，不求变量独立。若允许扩展值，同一等式仍可由非负项求和得到，但不能把它改写成两个无穷熵之差。

11.1.3 互信息衡量观察带来的减少量

定义 11.3 互信息与条件互信息 离散变量 X, Y 的**互信息**（mutual information, MI）定义为

$$I(X; Y) = \sum_{x,y} p(x, y) \log \frac{p(x, y)}{p(x)p(y)}. \quad (11.4)$$

其中 $p(x, y) = 0$ 的项约定为零；该对数比求和允许取值 $+\infty$ ，但不拆成两个可能无穷的熵之差。它比较实际联合质量 $p(x, y)$ 与独立情形

下的乘积质量 $p(x)p(y)$ 。给定 Z 后的**条件互信息**定义为先固定 $Z = z$ 计算同一对数比，再对 Z 平均：

$$I(X; Y | Z) = \sum_{z: p(z) > 0} p(z) \sum_{x, y} p(x, y | z) \log \frac{p(x, y | z)}{p(x | z)p(y | z)}. \quad (11.5)$$

上述定义不涉及无穷量相减。若 $H(X, Y) < \infty$ ，利用熵的链式法则可进一步写成

$$I(X; Y) = H(X) - H(X | Y) = H(Y) - H(Y | X). \quad (11.6)$$

因此它可以解释为观察一个变量后另一个变量平均减少的不确定性。条件互信息则先固定已有信息 Z ，再衡量 Y 还能给 X 提供多少信息。对每个 z ，对数和不等式保证内层求和非负，所以条件互信息也非负，并且可能为 $+\infty$ ；在可数离散情形中，它等于零当且仅当 $X \perp Y | Z$ 几乎处处成立。

定理 11.4 数据处理不等式 若离散随机变量满足 Markov 关系 $X \rightarrow Y \rightarrow Z$ ，即 $X \perp Z | Y$ ，并且相关互信息有限，则

$$I(X; Z) \leq I(X; Y).$$

证明. 对同一个联合分布按两种顺序使用互信息链式法则，有

$$I(X; Y, Z) = I(X; Y) + I(X; Z | Y) = I(X; Y),$$

$$I(X; Y, Z) = I(X; Z) + I(X; Y | Z) \geq I(X; Z).$$

第一行使用 Markov 关系，第二行使用条件互信息非负性。合并两式即得结论。 ■

这里的“处理”可以是确定映射，也可以是仅依赖 Y 的随机通道。结论说明后处理不能凭空增加关于 X 的信息，但不保证任意特定任务的误差严格变差；若处理丢弃的方向与任务无关，等号仍可能成立。一般可测空间上的版本不能依赖离散求和；下一节正式定义 KL 后，将用 KL 的数据处理性质回收这一表达，避免有限熵中的无穷量相减。

示例 11.5 一次带噪二元观测 令 X 在 $\{0, 1\}$ 上均匀分布，观测 $Y = X \oplus N$ ，其中 $N \sim \text{Bernoulli}(\varepsilon)$ 与 X 独立， $0 \leq \varepsilon \leq 1/2$ 。由于 Y 也均匀，

$$H(X) = \log 2, \quad H(X | Y) = -\varepsilon \log \varepsilon - (1 - \varepsilon) \log(1 - \varepsilon).$$

记二元熵函数为

$$H_b(u) = -u \log u - (1-u) \log(1-u), \quad 0 \leq u \leq 1,$$

其中沿用 $0 \log 0 = 0$ 的约定。所以

$$I(X; Y) = \log 2 - H_b(\epsilon).$$

当 $\epsilon = 0$ 时，观测完整揭示 X ；当 $\epsilon = 1/2$ 时，观测与 X 独立，互信息为零。该数值描述平均可辨识信息，不保证每次观测都恢复正确。

11.1.4 微分熵依赖坐标

若连续随机向量 $\mathbf{X} \in \mathbb{R}^d$ 具有密度 p ，并且 $\mathbb{E}|\log p(\mathbf{X})| < \infty$ ，定义 **微分熵** (differential entropy)

$$h(\mathbf{X}) = - \int p(\mathbf{x}) \log p(\mathbf{x}) d\mathbf{x}.$$

它可以为负，也不具有离散熵“至少为零”的性质。设 $g: \mathbb{R}^d \rightarrow \mathbb{R}^d$ 是满足第 8 章密度换元定理条件的 C^1 微分同胚，并且

$$\mathbb{E}[|\log |\det \mathbf{J}_g(\mathbf{X})||] < \infty.$$

此时 $\mathbf{Y} = g(\mathbf{X})$ 仍有密度，换元公式给出

$$h(\mathbf{Y}) = h(\mathbf{X}) + \mathbb{E}[\log |\det \mathbf{J}_g(\mathbf{X})|]. \quad (11.7)$$

特别地， $\mathbf{Y} = a\mathbf{X}$ 时 $h(\mathbf{Y}) = h(\mathbf{X}) + \log |a|$ 。坐标单位从米改成厘米就会改变微分熵，所以不能把它单独当成坐标不变的分布差异。互信息和 KL 中的 Jacobian 矩阵项会相消，在适当可逆变换下保持不变。更一般地，若 $\mathbf{Y} = \mathbf{A}\mathbf{X} + \mathbf{b}$ ，其中 $\mathbf{A} \in \mathbb{R}^{d \times d}$ 可逆，且相关积分有限，则

$$h(\mathbf{Y}) = h(\mathbf{X}) + \log |\det \mathbf{A}|.$$

微分熵为负并不矛盾。例如 X 在区间 $[0, 1/2]$ 上均匀分布时，密度为 2，故 $h(X) = -\log 2$ 。这反映密度值依赖坐标尺度，而不是出现了“负的不确定性”。

11.2 预测分布与对数评分

11.2.1 交叉熵把预测质量写成平均损失

真实分布为 P , 预测分布为 Q 。若二者在离散空间上的质量分别为 p, q , 观察 $X \sim P$ 后给预测者的**对数损失**为 $-\log q(X)$ 。其平均值

$$H(P, Q) = -\sum_x p(x) \log q(x) \quad (11.8)$$

称为**交叉熵** (cross-entropy)。它不是 Q 自身的不确定性, 而是用 Q 描述来自 P 的结果时付出的平均代价。

定义 11.6 相对熵 同一可测空间上的概率测度 P, Q 若满足 $P \ll Q$, 则 **相对熵** (relative entropy), 也称 KL 散度, 定义为

$$D_{\text{KL}}(P||Q) = \int \log \frac{dP}{dQ} dP. \quad (11.9)$$

若 $P \not\ll Q$, 约定 $D_{\text{KL}}(P||Q) = +\infty$ 。

由这个定义, 式 (11.4) 可简写为

$$I(X; Y) = D_{\text{KL}}(P_{XY}||P_X \otimes P_Y),$$

条件互信息则是条件联合分布与条件边缘乘积分布之间 KL 的平均。这也把前一节的离散求和推广到允许正则条件分布的一般可测空间。在离散情形中,

$$D_{\text{KL}}(P||Q) = \sum_x p(x) \log \frac{p(x)}{q(x)},$$

并且

$$H(P, Q) = H(P) + D_{\text{KL}}(P||Q). \quad (11.10)$$

真实分布固定时, 最小化交叉熵等价于最小化从 P 到 Q 的 KL 散度。以二值结果为例, 取 $P = \text{Bernoulli}(0.9)$ 和 $Q = \text{Bernoulli}(0.6)$, 则

$$D_{\text{KL}}(P||Q) \approx 0.2263,$$

$$D_{\text{KL}}(Q||P) \approx 0.3112.$$

两个方向使用不同分布作平均, 因而数值不同。若预测分布把结果 1 的概率改为零, 而真实分布仍给该结果正概率, 则前向交叉熵与 KL 都变为无穷。

11.2.2 Gibbs 不等式与严格适当性

定理 11.7 Gibbs 不等式 任意概率测度 P, Q 满足

$$D_{\text{KL}}(P||Q) \geq 0,$$

且在散度有限时，等号成立当且仅当 $P = Q$ 。

证明. 只需处理 $P \ll Q$ 的情形。以 $\mu = P + Q$ 为共同支配测度，密度记为 p, q ，并在 $\{p > 0\}$ 上令 $r = q/p$ 。由 $-\log u \geq 1 - u$,

$$D_{\text{KL}}(P||Q) = \mathbb{E}_P[-\log r] \geq 1 - \mathbb{E}_P[r].$$

若 Q 还在 P 的零集上放有质量，则 $\mathbb{E}_P[r] \leq 1$ ；故右侧非负。等号要求 $-\log r = 1 - r$ 在 P -几乎处处成立，也就是 $r = 1$ ，同时 Q 不能在 P 的零集上留下额外质量。因此 $P = Q$ 。 ■

式 (11.10) 与 Gibbs 不等式说明，对数评分在真实分布处取得唯一最小期望损失，因而是严格适当评分规则。这是一项总体期望性质：有限样本经验交叉熵最低的模型未必最接近真实分布，模型族限制、优化误差和样本误差仍需分别处理。对一般随机元素，互信息仍按

$$I(X; Y) = D_{\text{KL}}(P_{XY} || P_X \otimes P_Y)$$

定义，条件互信息则是正则条件分布之间 KL 的平均；这要求所在空间允许选取相应条件分布。Gibbs 不等式立即给出非负性，并且零值分别等价于联合分布等于边缘乘积、条件联合分布几乎处处等于条件边缘乘积。KL 链式法则还给出

$$I(X; Y, Z) = I(X; Y) + I(X; Z | Y),$$

只要相关正则条件分布存在；用扩展值形式陈述时不需要把互信息写成可能未定义的熵之差。

11.2.3 方向、支持与同一高斯位置族

KL 散度通常不对称。若 P 在某区域有正质量而 Q 给出零质量，则 $D_{\text{KL}}(P||Q) = +\infty$ ；反向散度是否有限取决于反向支持关系。即使两个方向都有限，数值也通常不同。因此“最小化 KL”必须说明哪个分布位于前面。KL 也不满足三角不等式。令 P, Q, R 依次为参数 0.1, 0.2, 0.3 的

Bernoulli 分布, 可算得

$$D_{\text{KL}}(P\|R) \approx 0.1163 > D_{\text{KL}}(P\|Q) + D_{\text{KL}}(Q\|R) \approx 0.0624.$$

对具有相同方差 $\sigma^2 > 0$ 的高斯位置族

$$P = \mathcal{N}(\mu, \sigma^2), \quad Q = \mathcal{N}(\nu, \sigma^2),$$

直接代入密度比可得

$$D_{\text{KL}}(P\|Q) = \frac{(\mu - \nu)^2}{2\sigma^2}. \quad (11.11)$$

同一计算可直接推广到向量平移。若

$$P = \mathcal{N}(\mu, \Sigma), \quad Q = \mathcal{N}(\nu, \Sigma),$$

其中 $\mu, \nu \in \mathbb{R}^d$, 共同协方差 $\Sigma \in \mathbb{R}^{d \times d}$ 对称正定, 则

$$D_{\text{KL}}(P\|Q) = \frac{1}{2}(\mu - \nu)^\top \Sigma^{-1}(\mu - \nu). \quad (11.12)$$

这里比较的是白化后的均值位移: 沿低方差方向移动相同欧氏距离更容易被观测区分。若共同协方差只半正定, 则还要检查两分布是否位于同一仿射支持上; 均值差不在 $\text{range}(\Sigma)$ 中时 KL 为无穷, 不能直接把逆矩阵替换成伪逆而省略支持条件。标量或向量公式的对称性都来自共同协方差, 并不代表一般 KL 具有对称性。

11.2.4 约束下的最大熵分布

只给出若干矩约束时, 可能有许多分布与已知信息相容。**最大熵原理**选择其中熵最大者, 即不额外加入约束未提供的集中结构。设参考测度为 μ , 要求密度 p 满足

$$\int p \, d\mu = 1, \quad \int T_j p \, d\mu = \tau_j, \quad j = 1, \dots, k.$$

若存在参数 λ 使

$$p_\lambda(x) = \exp\{\lambda^\top T(x) - A(\lambda)\}$$

满足这些约束, 其中 $A(\lambda) = \log \int e^{\lambda^\top T(x)} d\mu(x) < \infty$, 则对任意同样可行的密度 p ,

$$\begin{aligned} D_{\text{KL}}(p\|p_\lambda) &= \int p \log p \, d\mu - \lambda^\top \tau + A(\lambda) \\ &= -h(p) + h(p_\lambda) \geq 0. \end{aligned}$$

所以 p_λ 最大化熵, 且在几乎处处意义下唯一。该结论要求可行分布和归一化常数存在, 也要求相关积分有限。矩约束不可达、自然参数落在边界或熵无上界时, 形式上的 Lagrange 乘子方程不保证存在最大化分布。固

定均值 $\mathbf{m}$ 和正定协方差 Σ 时, 高斯分布 $\mathcal{N}(\mathbf{m}, \Sigma)$ 是这一论证的代表性实例。对任意具有同样均值、协方差且微分熵有限的密度 p , 高斯对数密度是关于 $\mathbf{x}$ 的二次式, 因此 $\mathbb{E}_p \log q = \mathbb{E}_q \log q$ 。于是

$$D_{\text{KL}}(p||q) = h(q) - h(p) \geq 0,$$

即

$$h(p) \leq \frac{1}{2} \log((2\pi e)^d \det \Sigma).$$

该结论是在固定参考坐标和协方差约束下比较微分熵, 不消除微分熵本身的坐标依赖性。

11.3 分布差异的不同对象

11.3.1 总变差控制事件与有界测试函数

定义 11.8 总变差距离 概率测度 P, Q 的**总变差距离** (total variation distance, TV) 定义为

$$d_{\text{TV}}(P, Q) = \sup_A |P(A) - Q(A)|. \quad (11.13)$$

若 P, Q 相对于共同测度 μ 有密度 p, q , 令 $A^* = \{p \geq q\}$, 则

$$d_{\text{TV}}(P, Q) = \frac{1}{2} \int |p - q| d\mu = P(A^*) - Q(A^*). \quad (11.14)$$

证明来自 $\int (p - q) d\mu = 0$: 正部与负部积分相等, 而任意事件上的差不超过正部积分。对任意满足 $\|f\|_\infty \leq 1$ 的可测函数,

$$|\mathbb{E}_P f - \mathbb{E}_Q f| \leq 2d_{\text{TV}}(P, Q).$$

反过来取 $f = 2\mathbb{1}_{A^*} - 1$ 达到等号。因此

$$2d_{\text{TV}}(P, Q) = \sup_{\|f\|_\infty \leq 1} |\mathbb{E}_P f - \mathbb{E}_Q f|. \quad (11.15)$$

总变差同时控制全部事件概率和全部有界测试函数的期望, 但对无界损失没有直接保证。若测试函数的值域是 $[0, 1]$, 常数可改进为

$$|\mathbb{E}_P f - \mathbb{E}_Q f| \leq d_{\text{TV}}(P, Q),$$

因为可用层析表示 $f(x) = \int_0^1 \mathbb{1}\{f(x) > t\} dt$, 再逐层应用事件概率差的定义。对 $P = \text{Bernoulli}(1/4)$ 和 $Q = \text{Bernoulli}(1/2)$, 总变差为 $1/4$, 取 $f(x) = x$ 恰好达到这个上界。

11.3.2 Hellinger 距离与 KL 控制

取共同支配测度 μ , 定义平方 Hellinger 距离

$$d_H^2(P, Q) = \frac{1}{2} \int (\sqrt{p} - \sqrt{q})^2 d\mu = 1 - \int \sqrt{pq} d\mu. \quad (11.16)$$

该值不依赖共同支配测度的选择。由

$$|p - q| = |\sqrt{p} - \sqrt{q}|(\sqrt{p} + \sqrt{q})$$

以及 Cauchy-Schwarz 不等式,

$$d_H^2(P, Q) \leq d_{TV}(P, Q) \leq \sqrt{2} d_H(P, Q).$$

左侧使用 $\sqrt{p} + \sqrt{q} \geq |\sqrt{p} - \sqrt{q}|$, 右侧使用 $\int (\sqrt{p} + \sqrt{q})^2 d\mu \leq 4$ 。

定理 11.9 Pinsker 不等式 任意概率测度 P, Q 满足

$$d_{TV}(P, Q) \leq \sqrt{\frac{1}{2} D_{KL}(P||Q)}. \quad (11.17)$$

证明. 若 KL 无限, 结论直接成立。否则 $P \ll Q$ 。取 $A = \{dP/dQ \geq 1\}$, 并记 $a = P(A)$ 、 $b = Q(A)$, 则 $a - b = d_{TV}(P, Q)$ 。把样本只映射成事件指标 $\mathbb{I}_A$, 对 A 及其补集分别应用对数和不等式, 得到 KL 的分组不等式

$$D_{KL}(P||Q) \geq a \log \frac{a}{b} + (1 - a) \log \frac{1 - a}{1 - b}.$$

右侧作为 a 的函数在 $a = b$ 处函数值和一阶导数为零, 二阶导数为 $1/[a(1 - a)] \geq 4$ 。Taylor 积分余项于是给出右侧至少为 $2(a - b)^2$, 移项即得结论。■

Pinsker 不等式把小 KL 转成小事件差异, 但反向一般不成立: 总变差很小仍允许 Q 在 P 有极小正质量的区域赋零, 从而使 KL 无限。不同差异之间只能沿已证明的方向使用。对刚才的二值分布,

$$d_H^2(P, Q) \approx 0.0341, \quad D_{KL}(P||Q) \approx 0.1308.$$

相应比较给出 $0.0341 \leq 0.25 \leq \sqrt{2} d_H(P, Q)$, 而 Pinsker 上界为 $\sqrt{0.1308/2} \approx 0.2557$ 。这些数值也表明, 不同差异即使可互相控制, 通常仍有不同尺度。

11.3.3 测试函数类与最大均值差异

许多任务只关心一类特定测试函数 $\mathcal{F}$ 。相应的 **积分概率度量** (integral probability metric, IPM) 为

$$d_{\mathcal{F}}(P, Q) = \sup_{f \in \mathcal{F}} |\mathbb{E}_P f - \mathbb{E}_Q f|. \quad (11.18)$$

选择所有绝对值不超过 1 的函数得到两倍总变差；选择所有 1-Lipschitz 函数将在第 11.6 节得到一阶 Wasserstein 距离。若 $\mathcal{H}$ 是第 4 章建立的再生核 Hilbert 空间，核 k 可测，并且

$$\mathbb{E}_P \sqrt{k(X, X)} < \infty, \quad \mathbb{E}_Q \sqrt{k(Y, Y)} < \infty,$$

则每个 $f \in \mathcal{H}$ 在两个分布下的期望都存在。取单位球作为 $\mathcal{F}$ ，便得到**最大均值差异** (maximum mean discrepancy, MMD)；它比较两个分布在该核单位球上能够产生的最大期望差。暂将相应的 Riesz 代表元写成核均值，可得

$$\begin{aligned} \text{MMD}(P, Q) &= \sup_{\|f\|_{\mathcal{H}} \leq 1} |\mathbb{E}_P f - \mathbb{E}_Q f| \\ &= \|\mathbb{E}_P[k(X, \cdot)] - \mathbb{E}_Q[k(Y, \cdot)]\|_{\mathcal{H}}. \end{aligned}$$

这个等式不需要预先假定 Hilbert 值积分。再生性质和 Cauchy-Schwarz 不等式给出

$$|\mathbb{E}_P f(X)| \leq \|f\|_{\mathcal{H}} \mathbb{E}_P \sqrt{k(X, X)}.$$

因此 $f \mapsto \mathbb{E}_P f(X)$ 是 $\mathcal{H}$ 上的有界线性泛函。Riesz 表示定理保证存在唯一的 $\mu_P \in \mathcal{H}$ ，使该泛函等于 $\langle f, \mu_P \rangle_{\mathcal{H}}$ ； μ_Q 同理。于是

$$\sup_{\|f\|_{\mathcal{H}} \leq 1} |\langle f, \mu_P - \mu_Q \rangle_{\mathcal{H}}| = \|\mu_P - \mu_Q\|_{\mathcal{H}},$$

达到上确界的方向在差非零时为其归一化。可测有界核自动满足上述可积条件。

核若具有特征性，MMD 为零才推出 $P = Q$ ；一般核可能只比较有限的一组矩或特征方向。例如在线性核 $k(x, y) = xy$ 下，核均值只记录普通均值。点质量 δ_0 与在 $\{-1, 1\}$ 上各取一半质量的分布均值都为零，MMD 也为零，但两个分布并不相同。

11.3.4 Rényi 散度与组合边界

对 $\alpha > 1$ 且 $P \ll Q$ ，**Rényi 散度** 定义为

$$D_{\alpha}(P \| Q) = \frac{1}{\alpha - 1} \log \mathbb{E}_Q \left[\left(\frac{dP}{dQ} \right)^{\alpha} \right]. \quad (11.19)$$

它直接度量似然比的 α 阶矩。适当条件下令 $\alpha \rightarrow 1$ 得到 KL；阶数越大，越强调似然比的高值区域。若 $P \not\ll Q$ ，约定 $D_\alpha(P\|Q) = +\infty$ ；若 $P \ll Q$ 但上述阶矩无限，散度也为无限。令 $L = dP/dQ$ 。概率空间上的 L^p 范数随 p 不减，再结合 $\log \mathbb{E}_Q[L^\alpha]$ 关于 α 的凸性，可得 $D_\alpha(P\|Q)$ 随阶数不减。Hölder 不等式还给出事件控制

$$P(A) \leq \exp\left(\frac{\alpha-1}{\alpha} D_\alpha(P\|Q)\right) Q(A)^{(\alpha-1)/\alpha}. \quad (11.20)$$

这条界要求同一方向的绝对连续；若 $Q(A) = 0 < P(A)$ ，相应 Rényi 散度必为无穷。对独立乘积分布，密度比相乘、积分分解，故

$$D_\alpha(P_1 \otimes P_2 \| Q_1 \otimes Q_2) = D_\alpha(P_1 \| Q_1) + D_\alpha(P_2 \| Q_2).$$

这解释了为何 Rényi 散度适合记录重复随机机制的信息代价。自适应机制中，第 t 步输出分布依赖历史，不能直接声称无条件独立；若对每个可能历史都有统一的条件散度上界，才可通过条件密度比和迭代期望得到相应组合界。具体地，若每个共同历史 $h_{<t}$ 下

$$D_\alpha(P_t(\cdot | h_{<t}) \| Q_t(\cdot | h_{<t})) \leq \varepsilon_t,$$

则把联合似然比写成条件似然比的乘积，从最后一步开始对其 α 次幂作条件期望，每次至多乘上 $e^{(\alpha-1)\varepsilon_t}$ 。迭代后得到

$$D_\alpha(P_{1:T} \| Q_{1:T}) \leq \sum_{t=1}^T \varepsilon_t.$$

界对每个历史统一成立是关键；若只在某个边缘历史分布下平均，下一步自适应选择可能偏向散度较大的历史。隐私分析使用这些结论时，还必须先固定相邻数据定义与输出机制，不能只看到某个散度数值便推出隐私保证。

11.4 换测度与信息控制

11.4.1 指数倾斜给出熵的变分表达

第 8.2 节说明， $P \ll Q$ 时可以用密度比把 P 下期望改写为 Q 下期望。若只知道 KL 而不掌握密度比的逐点上界，指数倾斜仍能控制换测度后的平均。

定理 11.10 Donsker-Varadhan 变分表达 设 $P \ll Q$ 。对每个有界可测函数 f ,

$$D_{\text{KL}}(P\|Q) \geq \mathbb{E}_P[f] - \log \mathbb{E}_Q[e^f]. \quad (11.21)$$

而且在扩展实数意义下,

$$D_{\text{KL}}(P||Q) = \sup_{f \text{ 有界可测}} \{ \mathbb{E}_P[f] - \log \mathbb{E}_Q[e^f] \}. \quad (11.22)$$

证明. 给定有界可测 f , 定义指数倾斜分布

$$\frac{dQ_f}{dQ} = \frac{e^f}{\mathbb{E}_Q[e^f]}.$$

此时 Q_f 与 Q 等价, 因而 $P \ll Q_f$. 若 $D_{\text{KL}}(P||Q) < \infty$, KL 的链式相减给出

$$\begin{aligned} D_{\text{KL}}(P||Q_f) &= \mathbb{E}_P \left[\log \frac{dP}{dQ} - f + \log \mathbb{E}_Q[e^f] \right] \\ &= D_{\text{KL}}(P||Q) - \mathbb{E}_P[f] + \log \mathbb{E}_Q[e^f]. \end{aligned}$$

左侧非负, 得到式 (11.21); 若左侧原 KL 为无穷, 不等式自动成立。

再令 $L = dP/dQ$, 并把 $\log 0$ 解释为 $-\infty$. 取有界截断

$$f_n = \max\{-n, \min\{\log L, n\}\}.$$

由于 $P(L = 0) = 0$, 且 $\mathbb{E}_P[(\log L)^-] = \int_{\{L < 1\}} L(-\log L) dQ < \infty$, 截断期望满足 $\mathbb{E}_P[f_n] \rightarrow \mathbb{E}_P[\log L] = D_{\text{KL}}(P||Q)$, 右侧允许为无穷。另一方面, $e^{f_n} \rightarrow L$, 并且 $e^{f_n} \leq 1 + L$, 所以支配收敛定理给出 $\mathbb{E}_Q[e^{f_n}] \rightarrow \mathbb{E}_Q[L] = 1$. 因此对应变分目标趋于 KL, 证明上确界达到所需的扩展实数值。若 $\log L$ 本身有界, 它可直接作为候选并取得等号; 一般情形只由上述有界截断序列逼近等号。 ■

一个有限例子可以直接核对倾斜的作用。令 Q 在两个点上各赋概率 $1/2$, 并取 $f = (0, \log 3)$ 。归一化常数为 $\mathbb{E}_Q e^f = 2$, 倾斜后 $Q_f = (1/4, 3/4)$ 。直接计算可得

$$\mathbb{E}_{Q_f} f - D_{\text{KL}}(Q_f||Q) = \log 2,$$

恰好等于对数归一化常数; 函数值较大的第二点从一半质量增加到四分之三。

11.4.2 换测度后的期望界

若 g 有界可测, 把定理用于 λg 即可得到下面的期望界。对无界函数, 设 $\lambda > 0$, $g \in L^1(P)$, 并且 $\mathbb{E}_Q[e^{\lambda g}] < \infty$. 令 $g_n = \max\{-n, \min\{g, n\}\}$, 对 λg_n 应用定理。由于 $|g_n| \leq |g|$ 且 $e^{\lambda g_n} \leq 1 + e^{\lambda g}$, 分别在 P 和 Q 下使用支配收

敛定理, 同样得到

$$\mathbb{E}_P[g] \leq \frac{D_{\text{KL}}(P||Q) + \log \mathbb{E}_Q[e^{\lambda g}]}{\lambda}. \quad (11.23)$$

因此使用式 (11.23) 前, 必须确认 $P \ll Q$ 、 P 下可积性和所用参数处的指数矩有限。进一步假设 $g \in L^1(Q)$, 并且在 Q 下对所有 $\lambda \in \mathbb{R}$ 都有

$$\log \mathbb{E}_Q e^{\lambda(g - \mathbb{E}_Q g)} \leq \frac{\lambda^2 \sigma^2}{2},$$

则

$$\mathbb{E}_P[g] - \mathbb{E}_Q[g] \leq \frac{D_{\text{KL}}(P||Q)}{\lambda} + \frac{\lambda \sigma^2}{2}.$$

对 λ 优化得到

$$\mathbb{E}_P[g] - \mathbb{E}_Q[g] \leq \sqrt{2\sigma^2 D_{\text{KL}}(P||Q)}. \quad (11.24)$$

这条界控制的是期望差。若需要高概率、同时对数据依赖对象成立的结论, 还要把数据随机性和候选选择纳入指数矩或联合控制。

11.4.3 信息稳定性与 PAC-Bayes 接口

设样本 S 经过随机学习算法产生输出 W 。取

$$P = P_{S,W}, \quad Q = P_S \otimes P_W,$$

则换测度代价恰为 $I(S; W)$ 。如果某个中心化泛化差 $g(S, w)$ 对每个固定 w 在 P_S 下具有统一高斯指数矩, 式 (11.24) 便把平均泛化差控制为互信息的平方根。这里的信息量衡量算法输出对样本的依赖, 不等同于参数个数。PAC-Bayes 使用相同代数, 但比较对象不同。设 P_0 是见数据前固定的参数先验, Q_S 是数据依赖的随机预测分布。对满足上一小节可积性和指数矩条件的参数函数 $f(\theta)$,

$$\mathbb{E}_{\theta \sim Q_S}[f(\theta)] \leq D_{\text{KL}}(Q_S||P_0) + \log \mathbb{E}_{\theta \sim P_0}[e^{f(\theta)}].$$

再对样本建立指数矩和高概率控制, 才得到具体 PAC-Bayes 风险界。一个确定性的换测度不等式本身不是泛化定理; 先验是否独立于评价样本、损失是否有界或次高斯、后验如何由数据选择, 都必须在具体结果中说明。

下面给出一个可以直接回用的基础版本。设 $S = (Z_1, \dots, Z_n)$ 独立同分布, 损失 $\ell(\theta, Z) \in [0, 1]$, 并定义

$$R(\theta) = \mathbb{E}[\ell(\theta, Z)], \quad \hat{R}_S(\theta) = \frac{1}{n} \sum_{i=1}^n \ell(\theta, Z_i).$$

令 P_0 与 S 独立, 并在观察样本前固定。对任意预先固定的 $\lambda > 0$ 和 $0 <$

$\delta < 1$, 以至少 $1 - \delta$ 的概率, 同时对所有 $Q \ll P_0$ 成立

$$\mathbb{E}_Q R(\theta) \leq \mathbb{E}_Q \hat{R}_S(\theta) + \frac{D_{\text{KL}}(Q \| P_0) + \log(1/\delta)}{\lambda} + \frac{\lambda}{8n}. \quad (11.25)$$

事实上, 对每个固定 θ , Hoeffding 引理给出

$$\mathbb{E}_S e^{\lambda(R(\theta) - \hat{R}_S(\theta))} \leq e^{\lambda^2/(8n)}.$$

先对 P_0 平均, 再用 Markov 不等式可知, 在同一个概率至少为 $1 - \delta$ 的事件上,

$$\mathbb{E}_{P_0} e^{\lambda(R - \hat{R}_S)} \leq \frac{e^{\lambda^2/(8n)}}{\delta}.$$

在这个事件内应用 Donsker-Varadhan 不等式, 便得到式 (11.25)。事件只涉及先验积分, 所以结论能同时覆盖事件发生后按数据选择的全部 Q 。若再用数据选择 λ 或 P_0 , 则需离散并集界、样本拆分或新的统一指数矩, 不能直接沿用这条同时性。

同一损失设定也给出信息稳定性的具体常数。若随机算法输出 W , 则对固定 w , $R(w) - \hat{R}_S(w)$ 在 P_S 下满足方差代理 $1/(4n)$ 的次高斯界。将联合分布 $P_{S,W}$ 与边缘乘积比较, 式 (11.24) 给出

$$|\mathbb{E}[R(W) - \hat{R}_S(W)]| \leq \sqrt{\frac{I(S; W)}{2n}}.$$

这是平均的有符号泛化差界, 不是对每个样本或每个算法输出都成立的高概率保证。

11.4.4 轨迹 KL 的链式分解

考虑随机序列 $Z_{0:T} = (Z_0, \dots, Z_T)$ 。设 P, Q 都按历史分解为

$$p(z_{0:T}) = p_0(z_0) \prod_{t=1}^T p_t(z_t | z_{<t}),$$

以及对应的 q , 并假设每个 P 条件核在相关历史上绝对连续于 Q 条件核。取对数似然比后求 P 下期望, 塔式性质给出

$$\begin{aligned} D_{\text{KL}}(P_{0:T} \| Q_{0:T}) &= D_{\text{KL}}(P_0 \| Q_0) \\ &+ \sum_{t=1}^T \mathbb{E}_{Z_{<t} \sim P} [D_{\text{KL}}(P_t(\cdot | Z_{<t}) \| Q_t(\cdot | Z_{<t}))]. \end{aligned} \quad (11.26)$$

这不是独立样本的乘积公式。每一步的分布可以依赖完整历史, 但条件 KL 必须沿 P 实际诱导的历史分布平均。在序贯决策中, 轨迹分布由环境转移与算法策略共同决定。若比较两个环境而保持同一算法, 算法在同一历史上的条件动作核相同, 可以在似然比中相消; 但两个环境产生的历史频率

仍不同，期望必须沿相应轨迹分布计算。若策略也改变，动作核的 KL 项不能省略。例如，在共同环境中比较两条历史依赖策略时，环境条件核逐项相消，剩余项是沿 P 轨迹平均的条件动作 KL 之和；在共同策略下比较两个环境时，动作核相消，剩余项则按该策略实际访问到的状态动作对累计环境条件 KL。访问次数因此是随机量，其期望由参考环境与算法共同决定，不能预先替换成均匀的独立样本数。

式 (11.26) 直接适用于固定有限时域。若在停时 $\tau \leq T$ 停止，可以在停止后补上共同的吸收符号，把问题化为长度 T 的轨迹；此时停止后的条件 KL 为零。无界停时则还需保证几乎处处终止，并对累计对数似然比建立可积控制或一致可积性，才能把有限截断的等式取极限。

11.5 信息论下界与难以区分的模型

11.5.1 二元检验的最小错误由总变差决定

设观测 Z 来自 P_0 或 P_1 ，两个假设先验各为 $1/2$ 。检验 $\psi(Z) \in \{0, 1\}$ 把某个事件 $A = \{\psi = 1\}$ 判为假设 1。两类错误之和为

$$P_0(A) + P_1(A^c) = 1 - \{P_1(A) - P_0(A)\}.$$

对 A 优化并使用总变差定义，得到

$$\inf_{\psi} \{P_0(\psi = 1) + P_1(\psi = 0)\} = 1 - d_{\text{TV}}(P_0, P_1). \quad (11.27)$$

这里的左侧是两类条件错误概率之和；在两个假设先验各为 $1/2$ 时，最小总体错误概率为

$$\frac{1}{2} \{1 - d_{\text{TV}}(P_0, P_1)\}.$$

所以分布的总变差越小，任何检验都越难同时降低两类错误。

11.5.2 Le Cam 两点方法

定理 11.11 Le Cam 两点下界 设两个模型 P_0, P_1 对应目标 θ_0, θ_1 ，并在度量 d 下满足 $d(\theta_0, \theta_1) \geq 2s$ 。对任意估计量 $\hat{\theta}$ ，

$$\max_{j \in \{0, 1\}} P_j(d(\hat{\theta}, \theta_j) \geq s) \geq \frac{1 - d_{\text{TV}}(P_0, P_1)}{2}. \quad (11.28)$$

证明. 由估计量构造检验

$$\psi = \mathbb{I}\{d(\hat{\theta}, \theta_1) < d(\hat{\theta}, \theta_0)\}.$$

若真实模型为 θ_0 但 $\psi = 1$, 三角不等式说明 $d(\hat{\theta}, \theta_0) \geq s$; 否则估计值同时离 θ_0 小于 s 且离 θ_1 更近, 会与两点距离至少 $2s$ 矛盾。模型 1 同理。因此两个估计坏事件的概率和至少为任意二元检验的错误和。使用式 (11.27), 再以最大值不小于平均值, 即得结论。 ■

若观察 n 个独立同分布样本, 则

$$D_{\text{KL}}(P_0^{\otimes n} \| P_1^{\otimes n}) = n D_{\text{KL}}(P_0 \| P_1).$$

结合 Pinsker 不等式, 可以用单样本 KL 控制 Le Cam 下界。例如对 $\mathcal{N}(-\delta, \sigma^2)$ 与 $\mathcal{N}(\delta, \sigma^2)$, 目标均值相距 2δ , 而 n 样本 KL 为 $2n\delta^2/\sigma^2$ 。取 δ 与 $\sigma/\sqrt{n}$ 同阶, 可使两模型仍不能可靠区分, 从而得到均值估计误差至少为 $n^{-1/2}$ 量级。这个构造给出下界量级, 不声称任意常数都最优。例如取 $\delta = \sigma/(2\sqrt{n})$, 则 n 样本 KL 等于 $1/2$, Pinsker 不等式给出总变差至多 $1/2$ 。式 (11.28) 于是说明, 对任何均值估计量, 至少在一个模型下, 以不小于 $1/4$ 的概率产生不小于 $\sigma/(2\sqrt{n})$ 的误差。这里常数来自所选两点和 Pinsker 放缩, 并非最优常数。

11.5.3 Fano 不等式处理多个候选

两点方法不能反映候选数随问题规模增长的困难。令随机索引 V 在 $\{1, \dots, M\}$ 上均匀, 给定 $V = v$ 后观测 $Z \sim P_v$ 。任意解码器 $\hat{V}(Z)$ 的错误概率记为 $p_e = \mathbb{P}(\hat{V} \neq V)^2$ 。

² T. M. Cover, J. A. Thomas, *Elements of Information Theory*, Wiley, 2006, 2nd ed.

定理 11.12 Fano 不等式 当 $M \geq 2$ 时,

$$p_e \geq 1 - \frac{I(V; Z) + \log 2}{\log M}. \quad (11.29)$$

证明. 令 $E = \{\hat{V} \neq V\}$ 。由于 $\hat{V}$ 是 Z 的函数,

$$\begin{aligned} H(V | Z) &\leq H(V, E | Z) \\ &= H(E | Z) + H(V | E, Z) \\ &\leq \log 2 + p_e \log(M-1) \\ &\leq \log 2 + p_e \log M. \end{aligned}$$

另一方面, V 均匀使 $H(V | Z) = H(V) - I(V; Z) = \log M - I(V; Z)$ 。合并两式并移项即得结论。 ■

为了把 Fano 不等式变成估计下界, 可在参数空间中选取一个 $2s$ -分离的有限打包 $\{\theta_1, \dots, \theta_M\}$ 。若估计误差小于 s , 最近邻解码就能恢复索引; 所

以解码错误蕴含估计误差至少为 s 。随后还需控制 $I(V; Z)$ ，常用上界为

$$I(V; Z) = \frac{1}{M} \sum_{v=1}^M D_{\text{KL}}(P_v \| \bar{P}) \leq \frac{1}{M^2} \sum_{v,u} D_{\text{KL}}(P_v \| P_u),$$

其中 $\bar{P} = M^{-1} \sum_u P_u$ 。打包既要目标相隔足够远，又要让观测分布的 KL 足够小；只完成其中一项不能得到有效下界。一个一维数值构造已经能展示两项约束如何配合。取 $M = 4$ ，令候选均值为 $\{-3a, -a, a, 3a\}$ ，每个候选产生 n 个方差为 σ^2 的独立高斯观测。这些均值两两至少相隔 $2a$ ，而有序候选对的平均平方距离为 $10a^2$ ，所以

$$I(V; Z) \leq \frac{5na^2}{\sigma^2}.$$

取 $a = \sigma/(4\sqrt{n})$ ，右侧为 $5/16$ 。代入 Fano 不等式可得 $p_e \gtrsim 0.274$ ，从而任意均值估计器都在某个候选下以非零常数概率产生至少 a 的误差。高维问题通常用更多分离方向使 $\log M$ 随维数增长，但仍须同时核对参数间损失与观测分布间 KL。

11.5.4 自适应访问下的轨迹下界

在强化学习或主动实验中，第 t 次观测位置由过去数据决定。此时不能把样本写成固定设计下的独立乘积。应对算法与环境共同诱导的轨迹分布使用式 (11.26)。若两个环境只在某些状态动作对上不同，轨迹 KL 通常具有

$$D_{\text{KL}}(\mathbb{P}_0^{\mathcal{A}} \| \mathbb{P}_1^{\mathcal{A}}) = \sum_{s,a} \mathbb{E}_0[N_T(s, a)] D_{\text{KL}}(P_0(\cdot | s, a) \| P_1(\cdot | s, a))$$

这样的访问次数分解。这里 $N_T(s, a)$ 本身由算法和环境决定。要推出样本复杂度或遗憾下界，还必须让两个环境的最优行动、奖励或价值确实相差一定量。仅构造轨迹分布接近的环境不够，因为它们可能要求完全相同的决策；仅构造价值不同的环境也不够，因为算法可能用一次观测就区分它们。信息下界的核心是同时满足“目标分离”和“观测接近”。例如有两个可选择来源 A, B 。环境 0 中二者回报均值分别为 $1/2 + \varepsilon$ 和 $1/2$ ，环境 1 只把 B 的均值改为 $1/2 + 2\varepsilon$ ，其中 $0 < \varepsilon < 1/4$ 。两个环境的最优来源相反，但全部区分信息只来自访问 B 时的 Bernoulli 观测。因而任意自适应算法的轨迹 KL 为

$$\mathbb{E}_0[N_T(B)] D_{\text{KL}}(\text{Bernoulli}(1/2) \| \text{Bernoulli}(1/2 + 2\varepsilon)).$$

若算法在两个环境中都以小错误概率选出最优来源，二元检验下界要求这个轨迹 KL 不能太小，从而迫使 $\mathbb{E}_0[N_T(B)]$ 达到相应量级。有限时域可直接使用该式；随机无界停止时刻还需沿用前节的终止与可积条件，不能无条件把 T 换成 τ 。

11.6 最优传输与分布距离

11.6.1 耦合描述质量怎样搬运

总变差关心同一事件上的质量差，KL 关心同一点上的密度比。若两个分布形状相同但位置略有平移，它们的支持甚至可能不重叠，此时 KL 可为无限，而“把质量移动多远”仍然很小。**最优传输** (optimal transport, OT) 正是寻找这种最小搬运代价³。给定空间 $\mathcal{X}, \mathcal{Y}$ 上的概率测度 P, Q ，**耦合** (coupling) 是边缘分别为 P, Q 的联合分布。全体耦合记为 $\Pi(P, Q)$ 。对非负成本 $c(x, y)$ ，Kantorovich 最优传输代价为

$$\mathcal{T}_c(P, Q) = \inf_{\gamma \in \Pi(P, Q)} \int c(x, y) d\gamma(x, y). \quad (11.30)$$

耦合决定来源质量与目标质量如何配对；优化在所有满足边缘约束的配对中选择成本最低者。在一般空间上，最小值是否达到需要额外条件。若 $\mathcal{X}, \mathcal{Y}$ 是 Polish 空间，也就是完备可分度量空间，成本 c 非负且下半连续，并且至少存在一个有限成本耦合，则存在有限成本的最优耦合。下面给出证明所用的拓扑概率接口。概率测度称为**紧的** (tight)，是指对任意 $\varepsilon > 0$ 都能找到紧集，使其外部质量小于 ε ；一族测度若可共用这个紧集，就称为**一致紧的** (uniformly tight)。Polish 空间上的每个概率测度都紧，因此可分别选择紧集 K_X, K_Y ，使任意 $\gamma \in \Pi(P, Q)$ 都满足

$$\gamma((K_X \times K_Y)^c) \leq P(K_X^c) + Q(K_Y^c) < \varepsilon.$$

所以全部耦合，特别是一列近最优耦合，构成一致紧族。Prokhorov 定理把一致紧性转成相对弱序列紧性，因而可取子列 $\gamma_k \Rightarrow \gamma$ ；这里弱收敛表示对每个有界连续函数 h ，都有 $\int h d\gamma_k \rightarrow \int h d\gamma$ 。把 h 取为只依赖一个坐标的有界连续函数，可知弱极限仍保持边缘 P, Q ，所以 $\gamma \in \Pi(P, Q)$ 。最后，Portmanteau 定理对非负下半连续成本给出

$$\int c d\gamma \leq \liminf_{k \rightarrow \infty} \int c d\gamma_k.$$

这里变化的是测度，不能直接把固定测度下的 Fatou 引理当作这一步的证明。在有限集合上，若来源质量为 p_i 、目标质量为 q_j ，成本为 $c_{i,j}$ ，问题是

$$\min_{\gamma_{i,j} \geq 0} \sum_{i,j} c_{i,j} \gamma_{i,j}, \quad \sum_j \gamma_{i,j} = p_i, \quad \sum_i \gamma_{i,j} = q_j.$$

这是第 3 章线性规划的直接实例。其对偶为

$$\max_{u,v} \left\{ \sum_i u_i p_i + \sum_j v_j q_j : u_i + v_j \leq c_{i,j} \right\}. \quad (11.31)$$

³ C. Villani, *Optimal Transport: Old and New*, Springer, 2009

这个约束可以从原问题完整消去搬运变量得到。分别用 u_i 和 v_j 乘两组边缘等式，并保留 $\gamma_{i,j} \geq 0$ 作为取下确界时的定义域，Lagrangian 为

$$\begin{aligned}\mathcal{L}(\boldsymbol{\gamma}, \mathbf{u}, \mathbf{v}) &= \sum_{i,j} c_{i,j} \gamma_{i,j} + \sum_i u_i \left(p_i - \sum_j \gamma_{i,j} \right) + \sum_j v_j \left(q_j - \sum_i \gamma_{i,j} \right) \\ &= \sum_i u_i p_i + \sum_j v_j q_j + \sum_{i,j} (c_{i,j} - u_i - v_j) \gamma_{i,j}.\end{aligned}\quad (11.32)$$

现在逐个消去 $\gamma_{i,j}$ 。若某个系数 $c_{i,j} - u_i - v_j < 0$ ，令相应 $\gamma_{i,j} \rightarrow +\infty$ 便使 $\inf_{\boldsymbol{\gamma} \geq 0} \mathcal{L} = -\infty$ ；若全部系数非负，下确界在 $\boldsymbol{\gamma} = \mathbf{0}$ 处达到，并等于 $\sum_i u_i p_i + \sum_j v_j q_j$ 。因此对偶函数为

$$g(\mathbf{u}, \mathbf{v}) = \begin{cases} \sum_i u_i p_i + \sum_j v_j q_j, & u_i + v_j \leq c_{i,j} \text{ 对所有 } i, j, \\ -\infty, & \text{否则.} \end{cases}$$

最大化这个对偶函数，正好得到式 (11.31)。约束 $u_i + v_j \leq c_{i,j}$ 不是额外猜出的条件，而是保证消去非负搬运变量后下确界有限的必要且充分条件。弱对偶也可由该约束逐项乘以 $\gamma_{i,j}$ 并求和得到；有限维可行且最优值有限时，线性规划强对偶保证两者相等。有限情形的存在性更直接：约束集合非空，因为独立耦合 $\gamma_{i,j} = p_i q_j$ 总是可行；它又是闭且有界的有限维多面体，所以线性目标能在其上取到最小值。耦合不必来自确定映射，一个源点的质量可以分送到多个目标点。

以位置 0, 2 上的两个分布为例，取 $\mathbf{p} = (3/4, 1/4)$ 、 $\mathbf{q} = (1/4, 3/4)$ ，成本 $c_{i,j} = |x_i - y_j|$ 。可行搬运表

$$\boldsymbol{\gamma} = \begin{pmatrix} 1/4 & 1/2 \\ 0 & 1/4 \end{pmatrix}$$

的成本为 1。对偶变量 $\mathbf{u} = (0, -2)$ 、 $\mathbf{v} = (0, 2)$ 满足全部 $u_i + v_j \leq c_{i,j}$ ，且对偶值同样为 $\mathbf{u}^\top \mathbf{p} + \mathbf{v}^\top \mathbf{q} = 1$ 。弱对偶说明任何可行搬运的成本至少为 1，所以上述表和势函数共同构成可核对的最优性证书。

11.6.2 Wasserstein 距离与矩条件

本小节假设 $(\mathcal{X}, d)$ 是 Polish 度量空间。固定 $x_0 \in \mathcal{X}$ ，并将具有有限 r 阶矩的概率测度记为

$$\mathcal{P}_r(\mathcal{X}) = \left\{ P : \int d(x, x_0)^r dP(x) < \infty \right\};$$

这个集合不依赖基点 x_0 的选择。对 $r \geq 1$ 和 $P, Q \in \mathcal{P}_r(\mathcal{X})$, 定义

$$W_r(P, Q) = \left[\inf_{\gamma \in \Pi(P, Q)} \int d(x, y)^r d\gamma(x, y) \right]^{1/r}. \quad (11.33)$$

在 $\mathcal{P}_r(\mathcal{X})$ 上, W_r 构成距离。三角不等式的关键是使用 Polish 空间上的粘合引理, 把 P, Q 的耦合与 Q, R 的耦合沿共同边缘 Q 粘合成三元联合分布, 再对 $d(X, Z) \leq d(X, Y) + d(Y, Z)$ 使用 Minkowski 不等式。若相应矩无限, 距离可以为无限。这些距离性质使用了底层 d 的非负、对称、点分离和三角不等式。一般自定义成本 $c(x, y)$ 得到的 $\mathcal{T}_c$ 仍是搬运代价, 但不自动对称, 也不自动满足三角不等式, 因而不能只因使用了耦合优化就称为距离。对 $r = 1$, 在上述 Polish 空间和有限一阶矩条件下, Kantorovich–Rubinstein 对偶给出

$$W_1(P, Q) = \sup_{\text{Lip}(f) \leq 1} |\mathbb{E}_P f - \mathbb{E}_Q f|. \quad (11.34)$$

因此若任务损失 f 关于输入是 L -Lipschitz, 就有

$$|\mathbb{E}_P f - \mathbb{E}_Q f| \leq L W_1(P, Q).$$

成本度量必须与任务敏感方向相符; 在无关坐标上代价很大, 可能使 Wasserstein 距离很大却不影响任务, 反之亦然。

11.6.3 同一高斯位置族下的三种比较

仍取

$$P = \mathcal{N}(\mu, \sigma^2), \quad Q = \mathcal{N}(\nu, \sigma^2).$$

令 $X \sim P$, 并取 $Y = X + \nu - \mu$, 得到一个耦合, 其位移恒为 $|\mu - \nu|$ 。另一方面, 任意耦合都满足

$$\mathbb{E}|X - Y|^2 \geq |\mathbb{E}X - \mathbb{E}Y|^2 = |\mu - \nu|^2.$$

所以

$$W_2(P, Q) = |\mu - \nu|. \quad (11.35)$$

与式 (11.11) 相比, Wasserstein 距离不除以噪声尺度, KL 则衡量平移相对于观测噪声有多容易辨认。例如当 $|\mu - \nu| = 0.2$ 、 $\sigma = 1$ 时,

$$\begin{aligned} W_2(P, Q) &= 0.2, \\ D_{\text{KL}}(P||Q) &= 0.02, \\ d_{\text{TV}}(P, Q) &= 2\Phi(0.1) - 1 \approx 0.0797, \end{aligned}$$

其中 Φ 为标准正态分布函数。若均值差保持不变而把 σ 减半, W_2 不变, KL 增至 0.08, 总变差也随可辨识性增大。若把两个点质量 $\delta_0, \delta_\varepsilon$ 比较, 则

$W_r(\delta_0, \delta_\varepsilon) = |\varepsilon|$, 但两个方向的 KL 在 $\varepsilon \neq 0$ 时都为无限, 因为支持不兼容。总变差则恒为 1, 不随 $\varepsilon \rightarrow 0$ 而减小。这说明三种差异的拓扑和任务含义不同, 不能只按数值大小互换。

11.6.4 分布演化与比较边界

一族随时间变化的分布 (P_t) 可以在 Wasserstein 空间中形成路径, 路径长度反映质量随时间移动的累计代价。这为平均场模型、粒子系统和连续生成过程提供几何语言。但边缘分布之间距离较小, 不自动说明产生这些边缘的轨迹机制接近; 路径依赖、条件转移和时间耦合仍需单独建模。MMD 与一阶 Wasserstein 距离都可写成测试函数类差异, 却选择不同函数类。MMD 的计算和统计性质依赖核, W_1 的含义依赖底层成本; 高阶 Wasserstein 距离仍由搬运代价定义, 并不具有这里的 IPM 表达。高维经验 Wasserstein 距离还可能收敛缓慢。选择哪一个不是纯粹的数学偏好, 应从任务损失、支持结构、可用矩条件和估计代价共同判断。

11.7 Fisher 几何与自然梯度

11.7.1 KL 的局部二阶项定义度量

设 $\{P_\theta : \theta \in \Theta \subseteq \mathbb{R}^d\}$ 是由共同测度支配的参数模型, 密度为 $p_\theta(x)$ 。固定内点 θ , 并假设存在其开邻域 $U \subseteq \Theta$ 与共同可测支持 S , 使所有 $\eta \in U$ 都满足 $p_\eta > 0$ 于 S 、在 S 外为零。再假设对几乎处处的 $x \in S$, 映射 $\eta \mapsto p_\eta(x)$ 二阶连续可微, 且其一、二阶导数分别由 μ -可积函数在 U 上一致控制。定义得分向量

$$\mathbf{s}_\theta(x) = \nabla_\theta \log p_\theta(x).$$

这些条件允许把一、二阶微分移入积分。由 $\int p_\theta d\mu = 1$,

$$\mathbb{E}_\theta[\mathbf{s}_\theta(X)] = \int \nabla_\theta p_\theta(x) d\mu(x) = \mathbf{0}. \quad (11.36)$$

为使下面两种 Fisher 表示都成为有限矩阵, 进一步假设

$$\mathbb{E}_\theta \|\mathbf{s}_\theta(X)\|_2^2 < \infty, \quad \mathbb{E}_\theta \left[\left\| \nabla_\theta^2 \log p_\theta(X) \right\|_{\text{op}} \right] < \infty.$$

定义 11.13 Fisher 信息矩阵 模型在 θ 处的 Fisher 信息矩阵定义为

$$\mathbf{F}(\theta) = \mathbb{E}_\theta[\mathbf{s}_\theta(X) \mathbf{s}_\theta(X)^\top]. \quad (11.37)$$

关键代数不能只把式 (11.36) 中的得分当作唯一依赖参数的对象。由乘积法则,

$$\nabla_\theta^2 p_\theta = p_\theta \left(\nabla_\theta^2 \log p_\theta + \mathbf{s}_\theta \mathbf{s}_\theta^\top \right).$$

在上述可积性和交换微分条件下，对两边积分并使用 $\int \nabla_{\theta}^2 p_{\theta} d\mu = \mathbf{0}$ ，得到信息恒等式

$$\mathbf{F}(\theta) = -\mathbb{E}_{\theta}[\nabla_{\theta}^2 \log p_{\theta}(X)].$$

前一个表达保证半正定，后一个表达把 Fisher 信息与期望对数似然曲率相连。支持随参数改变时，边界项可能破坏信息恒等式。

定理 11.14 KL 的局部二阶展开 除上述共同支持与密度导数条件外，假设 U 可取为凸集， $\mathbf{F}(\theta)$ 的所有元素有限，并且对 P_{θ} -几乎处处的 x ， $\nabla_{\eta}^2 \log p_{\eta}(x)$ 在 $\eta = \theta$ 处连续。进一步要求存在 $M \in L^1(P_{\theta})$ ，使

$$\sup_{\eta \in U} \|\nabla_{\eta}^2 \log p_{\eta}(x)\|_{\text{op}} \leq M(x)$$

几乎处处成立。则当 $\delta \rightarrow \mathbf{0}$ 且 $\theta + \delta \in U$ 时，

$$D_{\text{KL}}(P_{\theta} \| P_{\theta+\delta}) = \frac{1}{2} \delta^{\top} \mathbf{F}(\theta) \delta + o(\|\delta\|_2^2). \quad (11.38)$$

证明. 对固定 x ，沿线段 $\theta + t\delta$ 使用带积分余项的 Taylor 公式：

$$\begin{aligned} \log p_{\theta+\delta}(x) &= \log p_{\theta}(x) + \delta^{\top} \mathbf{s}_{\theta}(x) \\ &\quad + \int_0^1 (1-t) \delta^{\top} \nabla_{\eta}^2 \log p_{\eta}(x) \big|_{\eta=\theta+t\delta} \delta dt. \end{aligned}$$

把两边移入 $\mathbb{E}_{\theta}[\log p_{\theta} - \log p_{\theta+\delta}]$ 。一阶项由得分均值为零而消失。Hessian 的逐点连续性和 M 的可积控制允许使用支配收敛定理，得到

$$\int_0^1 (1-t) \mathbb{E}_{\theta} \left[\nabla_{\eta}^2 \log p_{\eta}(X) \big|_{\eta=\theta+t\delta} \right] dt = \frac{1}{2} \mathbb{E}_{\theta} [\nabla_{\theta}^2 \log p_{\theta}(X)] + o(1).$$

再使用信息恒等式 $\mathbb{E}_{\theta}[\nabla_{\theta}^2 \log p_{\theta}(X)] = -\mathbf{F}(\theta)$ ，并在两侧乘入 δ ，便得到二阶项及 $o(\|\delta\|_2^2)$ 余项。 ■

要让这个二次型成为切空间上的局部内积，还需假设得分映射满秩：对任意 $\mathbf{v} \neq \mathbf{0}$ ，都有 $\mathbb{E}_{\theta}[(\mathbf{v}^{\top} \mathbf{s}_{\theta}(X))^2] > 0$ 。这等价于 $\mathbf{F}(\theta)$ 正定，也可表述为参数到分布的映射在该点是正则浸入。局部可识别本身并不足够。例如一维高斯位置族 $P_{\theta} = \mathcal{N}(\theta^3, \sigma^2)$ 的参数映射一一对应，但

$$\mathbf{F}(\theta) = \frac{9\theta^4}{\sigma^2},$$

所以它在 $\theta = 0$ 处局部可识别却没有正定 Fisher 信息。在满足上述满秩条件的点，该局部内积就是 **Fisher 度量**：它按分布变化而不是坐标差衡量小

步长度。对高斯位置族 $\mathcal{N}(\mu, \sigma^2)$, 得分为 $(X - \mu)/\sigma^2$, 故

$$F(\mu) = \frac{1}{\sigma^2}.$$

局部长度 $|\mathrm{d}\mu|/\sigma$ 与 KL 公式完全一致: 噪声越小, 相同均值移动在分布上越显著。

11.7.2 自然梯度来自局部分布信赖域

设要最小化光滑目标 $L(\theta)$, 梯度为 $\mathbf{g} = \nabla L(\theta)$ 。欧氏最速下降取决于当前参数坐标的单位⁴。若改为限制一步引起的局部 KL 变化, 可解线性化信赖域问题

$$\min_{\boldsymbol{\delta}} \mathbf{g}^\top \boldsymbol{\delta} \quad \text{s.t.} \quad \frac{1}{2} \boldsymbol{\delta}^\top \mathbf{F}(\theta) \boldsymbol{\delta} \leq \varepsilon. \quad (11.39)$$

当 $\mathbf{F}$ 正定且 $\mathbf{g} \neq \mathbf{0}$ 时, Lagrange 驻点条件

$$\mathbf{g} + \lambda \mathbf{F} \boldsymbol{\delta} = \mathbf{0}$$

给出

$$\boldsymbol{\delta}^* = -\sqrt{\frac{2\varepsilon}{\mathbf{g}^\top \mathbf{F}^{-1} \mathbf{g}}} \mathbf{F}^{-1} \mathbf{g}. \quad (11.40)$$

也可以直接验证全局最优性。令 $\mathbf{u} = \mathbf{F}^{1/2} \boldsymbol{\delta}$, 则目标为 $(\mathbf{F}^{-1/2} \mathbf{g})^\top \mathbf{u}$, 约束为 $\|\mathbf{u}\|_2 \leq \sqrt{2\varepsilon}$ 。Cauchy-Schwarz 不等式说明最小值在 $\mathbf{u}$ 与 $-\mathbf{F}^{-1/2} \mathbf{g}$ 同向且位于边界时达到, 代回便得到式 (11.40)。若 $\mathbf{g} = \mathbf{0}$, 线性化目标在整个可行域上相同, 方向不由这个一阶问题唯一确定。方向 $-\mathbf{F}^{-1} \mathbf{g}$ 称为**自然梯度** (natural gradient) 方向。它是局部二阶近似下的最速下降方向; 有限步长下, 真实 KL 与二次近似之间仍有余项。

11.7.3 换坐标时为何保持同一切向变化

令新参数 ϕ 通过光滑可逆映射 $\theta = \theta(\phi)$ 给出, Jacobian 矩阵为 $\mathbf{J} = \partial\theta/\partial\phi$ 。链式法则给出

$$\mathbf{g}_\phi = \mathbf{J}^\top \mathbf{g}_\theta, \quad \mathbf{F}_\phi = \mathbf{J}^\top \mathbf{F}_\theta \mathbf{J}.$$

若 $\mathbf{J}$ 可逆且 Fisher 矩阵正定, 则

$$\mathbf{J} \mathbf{F}_\phi^{-1} \mathbf{g}_\phi = \mathbf{F}_\theta^{-1} \mathbf{g}_\theta.$$

所以两组坐标中的自然梯度对应同一个分布切向方向。这里的不变性是无穷小层面的; 具体离散更新、有限步长和数值近似仍可能随参数化改变。

⁴S.-i. Amari, *Natural Gradient Works Efficiently in Learning In Neural Computation*, 1998, vol. 10, no. 2, pp. 251–276

11.7.4 策略几何必须先确定分布对象

在序贯决策中，“策略的 Fisher 矩阵”至少可能指三种对象。固定状态 s 时，可以对单步动作分布 $\pi_{\theta}(\cdot | s)$ 取 Fisher 信息；也可以用指定访问分布 $d(s)$ 平均这些单步矩阵；还可以直接对完整轨迹分布求 Fisher 信息。三者分别衡量局部动作变化、访问加权的策略变化和累计轨迹变化。访问分布若也依赖参数，求导时是否将其视为固定会改变所得对象。条件高斯模型可以把几种常被混用的矩阵放在同一处比较。设在固定输入分布 d 下，

$$Y | \mathbf{X} = \mathbf{x} \sim \mathcal{N}(\boldsymbol{\theta}^\top \mathbf{x}, \sigma^2).$$

单个条件观测的得分、负对数似然 Hessian 和得分外积分别为

$$\begin{aligned} \mathbf{s}_{\theta}(\mathbf{x}, y) &= \frac{y - \boldsymbol{\theta}^\top \mathbf{x}}{\sigma^2} \mathbf{x}, \\ -\nabla_{\theta}^2 \log p_{\theta}(y | \mathbf{x}) &= \frac{\mathbf{x} \mathbf{x}^\top}{\sigma^2}, \\ \mathbf{s}_{\theta} \mathbf{s}_{\theta}^\top &= \frac{(y - \boldsymbol{\theta}^\top \mathbf{x})^2}{\sigma^4} \mathbf{x} \mathbf{x}^\top. \end{aligned}$$

在模型正确且 Y 按该条件分布平均时，残差平方的条件期望为 σ^2 ，后二者的条件期望相同；再对 $\mathbf{X} \sim d$ 平均，得到 $\mathbf{F} = \mathbb{E}_d[\mathbf{X} \mathbf{X}^\top] / \sigma^2$ 。但对一条具体样本，经验得分外积还乘着随机残差平方，并不等于观测 Hessian；模型失配或使用不同输入权重时，其总体平均也未必等于所定义的 Fisher 矩阵。若参数冗余或模型不可识别， $\mathbf{F}$ 可能奇异。Moore–Penrose 伪逆可在可辨识切向子空间选取最小范数解，但参数空间中的零空间分量仍不唯一。阻尼 $(\mathbf{F} + \lambda \mathbf{I})^{-1}$ 保证数值可逆，却加入了坐标相关的欧氏结构；经验 Fisher、分块近似或其他预条件矩阵若不等于真实分布 Fisher，也不能无条件继承上述坐标变换结论。

11.8 变分表达与概率学习

11.8.1 证据下界把难积分改写为分布优化

设联合模型为 $p_{\theta}(x, z)$ ，观测 x 固定，潜变量 z 需要积分：

$$p_{\theta}(x) = \int p_{\theta}(x, z) dz.$$

以下假设 $0 < p_{\theta}(x) < \infty$ ，并取与后验 $p_{\theta}(z | x)$ 相互绝对连续的概率密度 q ；同时假设下列对数比的正负部分可积。相互绝对连续一方面保证重要性比不会漏掉联合密度的正质量区域，另一方面保证从 q 到后验的 KL 有

定义且有限。将 q 乘除进积分，并对凹函数 $\log$ 使用 Jensen 不等式，

$$\begin{aligned}\log p_{\theta}(x) &= \log \mathbb{E}_q \left[\frac{p_{\theta}(x, Z)}{q(Z)} \right] \\ &\geq \mathbb{E}_q [\log p_{\theta}(x, Z) - \log q(Z)].\end{aligned}\quad (11.41)$$

右侧称为**证据下界** (evidence lower bound, ELBO)，记为 $\mathcal{L}(q, \theta; x)$ 。利用 $p_{\theta}(x, z) = p_{\theta}(z | x)p_{\theta}(x)$ ，可精确分解为

$$\log p_{\theta}(x) = \mathcal{L}(q, \theta; x) + D_{\text{KL}}(q(Z) \| p_{\theta}(Z | x)). \quad (11.42)$$

固定 θ 时，最大化 ELBO 等价于在所选变分族中最小化从 q 到真实后验的 KL。只有当变分族包含真实后验且优化达到全局最优时，下界才取等号。若同时更新 θ ，证据本身也在改变；近似后验误差、参数拟合误差和优化误差不能合并成一个“下界差”而不加区分。若只要求 $q \ll p_{\theta}(\cdot | x)$ ，KL 分解仍可在相应有限性条件下使用；但若后验在 q 的零集上还有正质量，前面的重要性采样等号不再成立。反过来，仅让 q 覆盖后验支持也不足以保证反向 KL 有限。两条推导使用哪一种支撑关系，必须分别核对。

一个线性高斯例子可以核对分解的数值。设 $Z \sim \mathcal{N}(0, 1)$ 、 $X | Z \sim \mathcal{N}(Z, 1)$ ，观察到 $x = 1$ 。此时证据为 $\mathcal{N}(0, 2)$ ，后验为 $\mathcal{N}(1/2, 1/2)$ 。若取 $q = \mathcal{N}(0, 1)$ ，则

$$\begin{aligned}\log p(x) &= -\frac{1}{2} \log(4\pi) - \frac{1}{4} \approx -1.5155, \\ D_{\text{KL}}(\mathcal{N}(0, 1) \| \mathcal{N}(1/2, 1/2)) &= \frac{1}{2} \left(2 + \frac{1}{2} - 1 + \log \frac{1}{2} \right) \approx 0.4034.\end{aligned}$$

因此 ELBO 约为 -1.9189 ，与证据对数的差恰为该 KL。多变量高斯中，若把 q 限制为分块独立族，同一恒等式仍成立，但不能表达的后验相关性会留在 KL 近似差距中。

11.8.2 Gibbs 分布是线性收益与 KL 代价的最优解

Donsker-Varadhan 表达也可反向写成分布优化。设参考分布为 P_0 ，并令 f 为有界可测函数。则

$$\log \mathbb{E}_{P_0}[e^f] = \sup_{Q \ll P_0} \{\mathbb{E}_Q[f] - D_{\text{KL}}(Q \| P_0)\}. \quad (11.43)$$

最优分布满足

$$\frac{dQ^*}{dP_0} = \frac{e^f}{\mathbb{E}_{P_0} e^f}.$$

记归一化常数为 $Z_f = \mathbb{E}_{P_0} e^f$ 。由于 f 有界, Q^* 下的 $\mathbb{E}_{Q^*} f$ 和 $D_{\text{KL}}(Q^* \| P_0)$ 都有限。对任意 $Q \ll P_0$, 若 $D_{\text{KL}}(Q \| P_0) = +\infty$, 约定目标为 $-\infty$; 否则

$$\begin{aligned} \mathbb{E}_Q[f] - D_{\text{KL}}(Q \| P_0) &= \log Z_f - D_{\text{KL}}(Q \| Q^*) \\ &\leq \log Z_f. \end{aligned}$$

取 $Q = Q^*$ 达到等号, 这便完整给出式 (11.43); 因此指数加权不是任意技巧, 而是在提高平均收益与偏离参考分布之间作精确权衡的解。若要允许无界 f , 仅有 $0 < Z_f < \infty$ 还不足以保证 Q^* 取得上确界; 例如 $\mathbb{E}_{P_0}[e^f |f|] < \infty$ 是保证上述两项有限的一个充分条件。只有归一化常数有限而该可积性不成立时, 截断倾斜分布仍可逼近上确界, 但不能把 Q^* 直接代入两个无穷项之差。若 f 的指数矩无限, 归一化常数不存在, 右侧优化也可能无有限解。对有界可测收益 r , 加入温度 $\beta > 0$ 时,

$$\sup_Q \{\mathbb{E}_Q[r] - \beta D_{\text{KL}}(Q \| P_0)\} = \beta \log \mathbb{E}_{P_0}[e^{r/\beta}],$$

且 $Q^* \propto P_0 e^{r/\beta}$ 。较小温度更强调高收益区域, 但也可能使密度比集中、采样方差增大; KL 正则约束的是相对参考分布的概率变化, 不是任务安全约束。

11.8.3 指数族与凸对偶

对指数族

$$p_\eta(x) = h(x) \exp\{\eta^\top T(x) - A(\eta)\},$$

第 8 章已得 $\nabla A(\eta) = \mathbb{E}_\eta T(X)$ 以及 $\nabla^2 A = \text{Cov}_\eta(T)$ 。对数配分函数的凸共轭为

$$A^*(\tau) = \sup_\eta \{\eta^\top \tau - A(\eta)\}. \quad (11.44)$$

若 τ 位于可实现均值参数集合的相对内部, 且存在 η 满足 $\nabla A(\eta) = \tau$, 则最优性条件给出

$$A^*(\tau) = \eta^\top \tau - A(\eta).$$

相对于基准密度 h 的负熵正是这一共轭量。于是自然参数 η 与均值参数 τ 形成对偶坐标, Fisher 矩阵 $\nabla^2 A(\eta)$ 把两者的局部变化联系起来。若指数族不是最小表示, 充分统计量之间存在线性冗余, A 不会严格凸, 均值参数与自然参数也不一一对应。边界均值可能只能由参数趋于无穷的极限实现。最大熵与凸对偶结论必须在可行域及其相对内部中解释。例如在有限集合 $\{0, 1, 2\}$ 上要求 $\mathbb{E}X = 1/2$, 相对于均匀计数测度的最大熵分布满足 $p_j \propto t^j$ 。矩约束给出

$$\frac{t + 2t^2}{1 + t + t^2} = \frac{1}{2}, \quad t = \frac{\sqrt{13} - 1}{6} \approx 0.4343,$$

从而 $(p_0, p_1, p_2) \approx (0.6162, 0.2676, 0.1162)$ 。这里优化变量是满足矩约束的分布, $t = e^\lambda$ 只是实现约束的乘子参数; 若改为拟合一个既定数据分布, 优化对象和保证都已改变。

11.8.4 学习目标中的变分量不等于概率保证

知识蒸馏常让学生分布 $Q_\phi(\cdot | x)$ 逼近教师分布 $P_T(\cdot | x)$ 。最小化 $D_{\text{KL}}(P_T \| Q_\phi)$ 等价于教师软标签下的交叉熵, 强调覆盖教师赋正质量的类别; 反向 KL 会采用不同的平均分布与支持要求。无论哪一方向, 学生得到的是对教师分布的逼近, 不自动比教师更接近真实标签分布。对比学习常把一个配对样本与若干负样本组成分类任务。适当采样条件下, 分类对数比可以形成互信息的变分下界; 但界的对象取决于正负样本的联合与边缘分布, 有限负样本数还会限制界的紧度。优化某个对比目标不能在未核对采样机制时直接解释为“最大化全部语义信息”。比较隐私机制输出时, KL 或 Rényi 散度可以作为变分控制中的代价; 正式隐私保证还要求对所有相邻输入统一成立, 并按机制组合规则换算。类似地, ELBO 较高只说明所选联合模型和变分族下的下界较高, 不等于后验已经校准, 也不等于生成样本满足任务评价。变分表达把难问题转成优化问题, 但不会替代模型假设、统计证据和任务保证。

11.9 本章小结

熵从平均描述长度刻画单个分布的不确定性, 条件熵和互信息说明已有信息与新增观测分别减少多少不确定性。对数评分把预测分布放入真实分布下评价, 交叉熵由真实熵与 KL 失配组成; 绝对连续性决定这种失配是否有限, KL 的方向决定重点覆盖哪些概率区域。分布差异没有唯一答案。总变差控制事件和有界测试函数, Hellinger 提供对称的平方根密度距离, MMD 只考察所选核函数类, Rényi 散度强调似然比高阶矩。Wasserstein 距离进一步把底层空间的搬运成本纳入比较, 因而能连续反映支持位置的移动。选择差异时必须说明要控制的事件、损失、矩或空间成本, 不能把一个距离的小值无条件替换成另一个距离的小值。换测度变分式把指数矩与 KL 代价连接起来, 可用于信息稳定性、PAC-Bayes 和轨迹比较。Le Cam 与 Fano 从相反方向说明, 如果目标彼此分离而观测分布仍接近, 任何估计器都必须承担误差; 自适应访问下应比较算法诱导的完整轨迹, 不能假装获得了固定设计的独立样本。在得分满秩的正则模型中, KL 的局部二阶项给出 Fisher 度量, 自然梯度据此限制一步造成的分布变化。奇异模型、阻尼与近似预条件会改变这项几何保证。ELBO、Gibbs 变分式和指数族凸对偶则说明, 许多概率学习目标都可看成在期望收益、熵与相对熵之间优化; 优化替代分布并不自动建立真实世界的概率保证。信息不足能够限制估计, 但观测分布能否回答干预问题, 还需要第 12 章进一步引入生

成机制与识别假设。

因果推断

第 10 章研究怎样从有限观测推断未知总体，第 11 章进一步说明观测分布接近会怎样限制统计区分。即使样本足够多，观测分布也只能告诉我们哪些变量一同出现、在什么条件下可以相互预测。若问题改成“主动改变一个因素以后，结果会怎样”，推断目标已经发生变化。接受培训的人平均成绩更高，可能是培训提高了成绩，也可能是基础较好的人更愿意参加培训；把成绩预测得很准，仍不能区分这两种解释。

本章沿用二元处理 T 、结果 Y 与处理前协变量 X ，比较三类问题。观测问题询问 $p(y | t, x)$ ，干预问题询问把处理主动设为 t 后的结果分布，反事实问题则询问同一个体在另一处理下会得到什么结果。三者使用相似的条件概率记号，却依赖不同信息。我们先构造一个无法由观测关联消除的歧义，再分别建立结构因果模型与潜在结果的表达。随后，调整公式说明哪些假设能够把干预效应化成可观测测量；假设不足时，部分识别保留所有仍与证据相容的答案，而不是用一个点估计掩盖缺失信息。

因果图在本章只承担表达生成假设所需的局部职责。我们会定义有向边、无环生成次序和几种三节点结构，但不预先使用完整图论。后续图论章将系统建立一般图结构；这里的重点是辨认每项因果结论究竟由数据、设计还是额外假设支持。

12.1 观测关联与生成结构

12.1.1 相同观测分布可以对应不同干预后果

先忽略协变量，只考虑二元处理 $T \in \{0, 1\}$ 和二元结果 $Y \in \{0, 1\}$ 。设未观测背景变量 $U \sim \text{Bernoulli}(1/2)$ 。下面两套机制都生成

$$\mathbb{P}(T = 0, Y = 0) = \mathbb{P}(T = 1, Y = 1) = \frac{1}{2},$$

而另外两个组合的概率为零。

第一套机制是

$$T = U, \quad Y = U. \quad (12.1)$$

处理和结果都由共同背景 U 决定, 改变 T 本身不会进入 Y 的生成式。第二套机制是

$$T = U, \quad Y = T. \quad (12.2)$$

这里背景决定处理, 处理再决定结果。两套机制在自然运行时都只有 $T = Y$ 的记录, 所以

$$\mathbb{P}(Y = 1 \mid T = 1) = 1, \quad \mathbb{P}(Y = 1 \mid T = 0) = 0.$$

无论观测样本增加多少, 这两个条件概率都完全相同。

现在主动把处理设为 t , 同时保留其余生成机制。对式 (12.1), 设置 $T = t$ 以后仍有 $Y = U$, 因而

$$\mathbb{P}(Y = 1 \mid \text{do}(T = t)) = \frac{1}{2}, \quad t \in \{0, 1\}.$$

对式 (12.2), 设置处理后有 $Y = t$, 所以

$$\mathbb{P}(Y = 1 \mid \text{do}(T = t)) = t.$$

两套机制的观测分布相同, 干预分布却不同。这是观测与干预的基本反例: 关联强度再大, 也不能单独决定改变处理的后果。缺少的不是更精确的分布估计, 而是关于变量怎样生成的约束。

12.1.2 结构因果模型明确什么可以被改变

结构因果模型 (structural causal model, SCM) 用结构方程描述每个内生变量怎样由其直接输入和外生背景生成。设内生变量为 $\mathbf{V} = (V_1, \dots, V_d)$, 外生变量为 $\mathbf{U}$, 模型写成

$$V_j = f_j(\text{pa}_j, U_j), \quad j = 1, \dots, d, \quad (12.3)$$

其中 pa_j 是进入第 j 个方程的其他内生变量。外生变量概括模型未继续解释的背景差异; 它们可以相关, 此时相关性表示尚未显式展开的共同原因。

若这些方程可以按某个顺序依次求值, 且后面的变量不再反过来决定前面的变量, 就得到 **无环** (acyclic) 结构。把每个变量画成节点, 并在 V_k 进入 f_j 时画有向边 $V_k \rightarrow V_j$, 便得到有向无环图。箭头在 SCM 中表示直接生成输入, 而不只是条件分布的一种分解方式。给定外生变量分布和全部结构方程, 按无环次序求值会诱导一个观测联合分布¹。

无环次序还给出解的存在性与唯一性。设节点按 $V_{j_1}, \dots, V_{j_d}$ 排列, 使每个父节点都先于其子节点。给定任意外生取值 $\mathbf{u}$, 第一个方程只依赖已经

¹ J. Pearl, *Causality: Models, Reasoning, and Inference*, Cambridge University Press, 2009, 2nd ed.

给定的外生量，因而唯一确定 v_{j_1} ；若前 $k-1$ 个变量已经确定，第 k 个方程的全部内生输入也已经确定，于是唯一得到 v_{j_k} 。归纳到 d 便得到唯一的 $\mathbf{v}(\mathbf{u})$ 。外生分布通过映射 $\mathbf{u} \mapsto \mathbf{v}(\mathbf{u})$ 推前，形成观测分布。循环方程没有这种递归保证：它可能无解或有多个解，必须另外规定平衡选择、动态过程或其他解条件。

对变量 T 作**干预** (intervention) $\text{do}(T = t)$ ，表示删除原来生成 T 的结构方程，并用常量方程 $T = t$ 替换；其他方程和外生变量分布保持不变。对具有密度或质量函数的无环模型，若各局部机制由相互独立的外生噪声驱动，并且观测分布按因果图分解为

$$p(\mathbf{v}) = \prod_{j=1}^d p(v_j | \text{pa}_j),$$

则单节点理想干预后的**截断分解**为

$$p(\mathbf{v}_{-T} | \text{do}(T = t)) = \prod_{j: V_j \neq T} p(v_j | \text{pa}_j) \Big|_{T=t}. \quad (12.4)$$

这条公式不是从任意概率图自动得到的。只有当局部条件分布被解释为在干预下保持不变的生成机制时，删除处理节点的原机制才有因果含义。

固定值干预只是机制替换的一种。**随机干预** (stochastic intervention) 可以把处理方程替换为由新外生随机量驱动的规则，使给定处理前信息 $X = x$ 时的新分配分布为 $q(t | x)$ 。在前述独立外生噪声假设和简单结构 $X \rightarrow T$ 、 $X \rightarrow Y$ 、 $T \rightarrow Y$ 下，若其余机制保持不变，干预后的联合分布为

$$p^q(x, t, y) = p(x)q(t | x)p(y | t, x). \quad (12.5)$$

确定性策略是 $q(\cdot | x)$ 集中在某个动作上的特例。式 (12.5) 仍是一项机制假设：策略若同时改变结果测量、参与人群或其他生成规则，就不能只替换处理因子。

12.1.3 共同原因、中介与碰撞点

三个变量的局部结构已经能说明调整变量时最常见的差别。结构

$$T \leftarrow X \rightarrow Y$$

把 X 称为 T 与 Y 的**共同原因** (common cause)。即使 T 不影响 Y ，不同 X 人群采用处理的比例不同，也会使 T 与 Y 在观测中相关。这就是混杂产生的一条路径。

结构

$$T \rightarrow M \rightarrow Y$$

中的 M 是**中介变量** (mediator)。若目标是处理的总效应，把 M 固定后比较会阻断一部分真实作用；若目标是直接效应，则需要另外定义允许保留或阻断哪些路径。“加入更多控制变量”因此不是无条件正确的策略。

结构

$$T \rightarrow C \leftarrow Y$$

中的 C 是**碰撞点** (collider)，因为两条箭头在它处相遇。未给定 C 时，这条路径不必产生关联；只选择 C 取某些值的样本或在回归中给定 C ，反而可能使 T 与 Y 相关。关联是否出现以及方向如何，取决于具体的选择机制。例如，若两个独立能力共同决定总分，入选要求总分超过阈值，且两种能力可以相互补偿，那么只考察已入选者时，一种能力较弱的人往往需要在另一种能力上更强。若入选规则改为两项能力分别超过各自阈值，这种负关联则未必出现。无论哪种情形，由选择产生的关联都不能解释为任一能力造成另一能力。

共同原因适合在效应识别时调整，中介是否调整取决于目标，碰撞点通常不应仅因它可观测就调整。这三种判断依赖箭头的因果语义。若一张有向图只记录 $p(\mathbf{v}) = \prod_j p(v_j \mid \text{pa}_j)$ ，它表达的是概率约束，不能单凭箭头方向回答式 (12.4) 中的干预问题。

图 12.1 把三种局部结构放在同一视野中。双边框表示把中间节点加入条件集；共同原因与中介是非碰撞点，给定后会关闭相应路径，碰撞点的行为恰好相反。




图 12.1 共同原因、中介与碰撞点的局部路径。双边框节点表示已加入条件集，因而图形不只依赖颜色传达条件化。面板 (a)、(b) 中的中间节点是非碰撞点，给定后关闭路径；面板 (c) 中的中间节点是碰撞点，给定后反而打开路径。

12.1.4 d-分离把路径阻断转成条件独立

为了把三节点判断推广到较大的有向图，需要同时检查处理与结果之间的每条路径。设 $\mathcal{G} = (V, E)$ 为有向无环图。这里的**路径** (path) 是忽略箭头方向后，由相邻且互不重复的节点组成的序列；只有明确称为**有向路径** (directed path) 时，才要求沿箭头方向前进。若从节点 v 出发，沿长度至少为一的有向路径能够到达节点 w ，就称 w 为 v 的**后代** (descendant)，并

称 v 为 w 的 **祖先** (ancestor)。本章的祖先与后代均要求路径长度至少为一，因而不把节点自身计入其中。

定义 12.1 活跃路径与 d-分离 给定条件节点集 $S \subseteq V$ 。路径上的内部节点 v_i 若在该路径上呈现 $v_{i-1} \rightarrow v_i \leftarrow v_{i+1}$ ，就称为**碰撞点** (collider)；否则为非碰撞点。路径在给定 S 时**活跃** (active)，当且仅当每个非碰撞点都不在 S 中，并且每个碰撞点自身或它的至少一个后代在 S 中。

对两两不交的节点集 $A, B, S \subseteq V$ ，若连接 A 中任一节点与 B 中任一节点的每条路径都不活跃，就称 A 与 B 被 S **d-分离** (d-separated)，记为 $A \perp_g B \mid S$ ；否则称为 d-连接。

这一定义中，给定非碰撞点会关闭路径，给定碰撞点或其后代却会打开原本关闭的路径。例如，考虑同时含有

$$X \rightarrow M \rightarrow Y, \quad X \rightarrow C \leftarrow Y, \quad C \rightarrow D$$

的图。 X 与 Y 之间有经过 M 的链式路径和经过 C 的碰撞路径。不给定任何节点时，前一条路径活跃而后一条关闭，所以 X 与 Y 仍然 d-连接。给定 $S = \{M\}$ 会关闭链式路径，碰撞路径也仍关闭，因而 $X \perp_g Y \mid M$ 。若改为给定 $S = \{M, C\}$ ，碰撞点 C 被打开；给定 $S = \{M, D\}$ 时， C 的后代 D 被给定，也会打开同一条路径。这两种情况下 X 与 Y 都重新 d-连接。这个例子也说明，只检查一条路径是否关闭并不足以判断 d-分离。第 14 章将把路径、分离和结构分解放回一般图对象中；本章只使用有向无环图上的这套条件化判据。

图 12.2 画出了条件集 $S = \{M\}$ 的情形。经过 M 的链式路径被关闭，经过 C 的碰撞路径仍关闭，所以两条路径同时被阻断。




图 12.2 多条路径下的 d-分离。双边框节点 M 属于条件集，因而上方链式路径关闭；碰撞点 C 及其后代 D 均未给定，所以下方路径也关闭。若把 C 或 D 加入条件集，下方路径会重新打开。

分布 p 相对于因果图 $\mathcal{G}$ 满足**因果 Markov 性** (causal Markov property), 是指对任意两两不交的节点集 A, B, S , 都有

$$A \perp_{\mathcal{G}} B \mid S \implies \mathbf{V}_A \perp \mathbf{V}_B \mid \mathbf{V}_S,$$

其中 $\mathbf{V}_A$ 表示由节点集 A 中的随机变量组成的向量, $\mathbf{V}_B$ 与 $\mathbf{V}_S$ 同理。对有向无环图, 这一全局表述等价于局部表述: 每个变量在给定其父节点后, 与其非后代中除父节点外的变量条件独立。在无环 SCM 和相互独立的外生噪声条件下, 可以沿逆拓扑次序逐个积分掉无关后代; 每次只留下当前节点的条件因子, 由此得到局部 Markov 性和全局 d-分离结论。完整的图分解与消元工具由第 14 章继续建立。

12.2 干预与潜在结果

12.2.1 主动设置不同于观察到某个取值

观察 $T = t$ 会筛选自然机制恰好产生该取值的个体, 因此

$$p(y \mid T = t)$$

同时包含处理作用和进入处理组的选择机制。干预

$$p(y \mid \text{do}(T = t))$$

则先切断处理的自然生成机制, 再考察其余机制产生的结果。第 12.1 节的反例具体计算的是事件 $Y = 1$ 的概率: 两套机制中都有 $\mathbb{P}(Y = 1 \mid T = t) = t$; 在共同原因机制中, $\mathbb{P}(Y = 1 \mid \text{do}(T = t)) = 1/2$, 而在直接作用机制中, 该概率等于 t 。这些等式说明观察条件分布与干预分布不能通过省略 do 符号互换。

12.2.2 潜在结果把不同处理下的结果并列表示

潜在结果 (potential outcome) $Y(t)$ 表示把处理设为 t 时, 该研究单位将得到的结果。对二元处理, 每个单位都有一对数学对象

$$(Y(0), Y(1)),$$

但实际只能观察当前处理对应的一个结果²。

对二元处理, 常见总体目标是**平均处理效应** (average treatment effect, ATE)

$$\tau = \mathbb{E}[Y \mid \text{do}(T = 1)] - \mathbb{E}[Y \mid \text{do}(T = 0)]. \quad (12.6)$$

它比较两个干预总体的平均结果, 并不要求同一时刻让一个个体同时接受

² M. A. Hernán, J. M. Robins, *Causal Inference: What If*, Chapman & Hall/CRC, 2020

两种处理。若目标总体、处理版本或结果测量时间改变，式 (12.6) 所定义的量也会改变。

若处理取值属于有限集合 $\mathcal{T}$ ，则定义相应的一组潜在结果 $\{Y(t) : t \in \mathcal{T}\}$ ，任意两个处理的平均对比为

$$\tau(t, t') = \mathbb{E}[Y(t) - Y(t')].$$

多值处理并不只是多写几个二元比较：重叠条件要对目标中使用的每个处理值成立，剂量的物理含义和允许比较的处理版本也必须一致。连续处理还需要局部支持和相应的平滑条件，不能直接把每个精确剂量当作拥有正概率的离散组。

个体处理效应是 $Y(1) - Y(0)$ ，平均处理效应也可以写成

$$\tau = \mathbb{E}[Y(1) - Y(0)] = \mathbb{E}[Y(1)] - \mathbb{E}[Y(0)]. \quad (12.7)$$

线性期望使第二个等号成立；它没有使无法同时观察的两个个体结果变得可见。

SCM 与潜在结果可以在同一机制下对应起来。若结果方程为

$$Y = f_Y(T, X, U_Y),$$

则保持 X, U_Y 不变并把处理输入替换为 t ，得到

$$Y(t) = f_Y(t, X, U_Y). \quad (12.8)$$

因此

$$\mathcal{L}(Y(t)) = \mathcal{L}(Y \mid \text{do}(T = t)).$$

潜在结果侧重比较处理方案，SCM 还显式说明变量间的生成顺序和连带变化。两种语言能够描述同一目标，但一个潜在结果表本身未必给出完整的多变量结构方程。

12.2.3 一致性、干扰与处理机制

要把观察结果连接到潜在结果，至少要明确三类条件。**一致性** (consistency) 要求实际接受处理 t 的单位满足

$$T = t \implies Y = Y(t), \quad \text{也可写作} \quad Y = TY(1) + (1 - T)Y(0). \quad (12.9)$$

它说明观测结果等于实际处理对应的潜在结果。若“接受培训”包含时长、教师和课程完全不同的版本，却仍用一个二元 T 表示，一致性可能没有良好定义。

无干扰要求一个单位的结果不随其他单位的处理改变。若有 n 个单位, 更一般的潜在结果应写成 $Y_i(\mathbf{t})$, 而不是只写 $Y_i(t_i)$ 。疫苗、社交网络 and 市场竞争中, 一个人的处理会改变他人的暴露或机会, 无干扰通常不成立。此时需要定义分组、网络暴露或总体处理比例, 不能继续把单个处理变量的 ATE 解释为全部作用。

“稳定单位处理值”常把处理版本唯一性与无干扰合在一起。它们与处理分配机制仍是不同条件。分配机制规定 T 怎样依赖 $X, Y(0), Y(1)$ 等变量; 一致性只连接已经接受的处理与观察结果, 并不保证处理像随机试验那样分配。即使处理定义清楚且单位互不干扰, 主动选择处理的人仍可能与未选择者具有不同潜在结果。

12.3 因果效应的识别条件

12.3.1 识别、估计与计算回答不同问题

给定一组模型假设, 若所有产生同一可观测分布的允许机制都给出相同目标值, 就称该目标 **可识别** (identifiable)。识别是总体层面的唯一确定性。它不表示有限样本估计已经准确, 也不表示求解某个估计式的优化算法一定稳定。反过来, 一个算法可以精确拟合全部观测条件分布, 却因第 12.1 节的两套机制而无法确定干预效应。

随机试验通过设计建立识别。若处理由独立随机装置分配, 且两种处理都有正概率, 则

$$(Y(0), Y(1)) \perp T.$$

结合一致性, 对 $t \in \{0, 1\}$ 和任意可测集合 B 有

$$\mathbb{P}(Y(t) \in B) = \mathbb{P}(Y(t) \in B \mid T = t) = \mathbb{P}(Y \in B \mid T = t). \quad (12.10)$$

第一步使用随机分配, 第二步使用一致性。因此, 随机试验识别每个潜在结果的完整边缘分布; 它并不据此识别 $Y(0)$ 与 $Y(1)$ 在同一个体上的联合分布。结果可积时, 取均值得到

$$\begin{aligned} \mathbb{E}[Y(t)] &= \mathbb{E}[Y(t) \mid T = t] \\ &= \mathbb{E}[Y \mid T = t]. \end{aligned}$$

处理组与对照组的均值差因而识别 ATE。若存在失访、不依从、处理溢出或随机化后选择样本, 原有独立性需要按实际分析目标重新检查。

12.3.2 条件交换性与支持重叠

观察研究常希望用处理前协变量 X 解释分配差异。核心条件是 **条件交换性** (conditional exchangeability)

$$(Y(0), Y(1)) \perp T \mid X. \quad (12.11)$$

它表示在固定 X 以后, 处理组和未处理组的潜在结果分布可以交换。白话地说, X 已经包含同时影响处理选择和结果的共同原因。该条件涉及无法同时观察的潜在结果, 不能仅凭处理预测准确率或结果拟合误差从数据中验证。

还需要**支持重叠** (overlap), 也称**正值性** (positivity)。记倾向概率

$$e(x) = \mathbb{P}(T = 1 \mid X = x).$$

对目标总体中几乎处处的 x , 要求

$$0 < e(x) < 1. \quad (12.12)$$

若某类人必然接受或必然不接受处理, 观测数据便没有该类人在另一处理下的参照。交换性说明现有参照为何可比, 重叠说明参照确实存在; 两者不能互相替代。

正值性的作用域由目标决定, 不是要求数据在所有可能协变量和行动上处处有正密度。识别 $\mathbb{E}[Y(1)]$ 只要求目标总体几乎处处满足 $e(x) > 0$, 识别 $\mathbb{E}[Y(0)]$ 只要求 $e(x) < 1$, 而目标总体 ATE 同时需要两侧条件。对随机目标策略 $q(t \mid x)$, 相应要求是: 只要目标策略在目标总体的某个 x 上给行动 t 正概率, 观测分配机制也必须给该行动正概率。目标总体支持之外的 x 或目标策略从不采用的行动不在这项要求内。接近零但不等于零的倾向概率不会破坏总体层面的点识别, 却会产生大权重和有限样本不稳定; 这属于可估计性与精度问题。

12.3.3 调整公式的推导

在一致性、条件交换性和重叠成立时, 对 $t \in \{0, 1\}$, 全期望公式给出

$$\mathbb{E}[Y(t)] = \mathbb{E}_X[\mathbb{E}[Y(t) \mid X]].$$

条件交换性允许在内层加入实际处理条件:

$$\mathbb{E}[Y(t) \mid X] = \mathbb{E}[Y(t) \mid T = t, X].$$

重叠保证右侧在目标总体所需的 X 取值上由相应处理组定义，一致性再把潜在结果换成观察结果。于是

$$\mathbb{E}[Y(t)] = \mathbb{E}_X[\mathbb{E}[Y | T = t, X]]. \quad (12.13)$$

这就是单时点处理的调整公式。令 $\mu_t(x) = \mathbb{E}[Y | T = t, X = x]$ ，ATE 被识别为

$$\tau = \mathbb{E}_X[\mu_1(X) - \mu_0(X)]. \quad (12.14)$$

同一目标还可写成逆概率加权形式。利用条件期望，对处理组有

$$\begin{aligned} \mathbb{E}\left[\frac{TY}{e(X)} \middle| X\right] &= \frac{\mathbb{P}(T = 1 | X)}{e(X)} \mathbb{E}[Y | T = 1, X] \\ &= \mu_1(X). \end{aligned}$$

对未处理组同理可得

$$\mathbb{E}\left[\frac{(1-T)Y}{1-e(X)} \middle| X\right] = \mu_0(X).$$

再取总体期望，得到

$$\tau = \mathbb{E}\left[\frac{TY}{e(X)} - \frac{(1-T)Y}{1-e(X)}\right]. \quad (12.15)$$

调整公式与加权公式是同一识别关系的两种表示。有限样本中如何估计 μ_t 或 e 、怎样交叉拟合以及如何报告不确定性，属于估计问题；它们不能修复交换性错误或支持缺口。

12.3.4 后门准则解释哪些变量适合调整

潜在结果条件交换性直接说明调整公式为何成立，但它没有告诉我们应把哪些变量放进 X 。在具有生成语义的 DAG 中，从 T 到 Y 且第一条边指向 T 的路径称为 **后门路径** (back-door path)；它描述处理自然生成机制与结果之间的非因果联系。集合 Z 满足一项常用的**后门准则** (back-door criterion)，如果 Z 不包含 T 的后代，并且给定 Z 能阻断 T 与 Y 之间的全部后门路径。这里的“阻断”按定义 12.1 判断，因而把碰撞点放入 Z 可能打开路径。

最基本的代表图为 $Z \rightarrow T$ 、 $Z \rightarrow Y$ 、 $T \rightarrow Y$ 。其观测分解是

$$p(z, t, y) = p(z)p(t | z)p(y | t, z).$$

执行 $\text{do}(T = t)$ 时删除 $p(t | z)$ ，再对 Z 积分，得到

$$p(y | \text{do}(T = t)) = \int p(y | t, z)p(z) dz. \quad (12.16)$$

一般后门准则把同一推导推广到多条路径： Z 阻断所有进入 T 的非因果路径，使给定 Z 后的处理比较不再携带这些路径造成的差异； Z 又不是处理后代，所以干预不会先改变用于平均的 $p(z)$ 。在因果 Markov 性和所声明 DAG 包含相关共同原因等条件下，这给出式 (12.16)。

三个局部图可以核对这项准则。在 $T \leftarrow X \rightarrow Y$ 中， X 阻断后门路径；在 $T \rightarrow M \rightarrow Y$ 中， M 是处理后代，调整它会改变总效应目标；在 $T \rightarrow C \leftarrow Y$ 中，空集已经关闭碰撞路径，加入 C 反而将其打开。因此，“处理前测量”“与结果相关”或“能提高预测精度”都不是充分的调整标准。后门准则是充分条件而不是识别的必要条件；它失败时，随机设计、其他图识别规则或更具体的结构假设仍可能识别目标。

12.3.5 一个可复核的混杂算例

设 $X \in \{0, 1\}$ 表示处理前风险，且 $\mathbb{P}(X = 1) = 1/2$ 。高风险者更常接受处理：

$$e(1) = 0.8, \quad e(0) = 0.2.$$

假定给定 X 后处理满足交换性，并设潜在结果均值为

	$X = 0$	$X = 1$
$\mathbb{E}[Y(0) X]$	0.1	0.5
$\mathbb{E}[Y(1) X]$	0.3	0.7

这些数值是教学构造，不代表真实试验。两个风险层中的处理效应都为 0.2，因此

$$\tau = \frac{1}{2}(0.3 - 0.1) + \frac{1}{2}(0.7 - 0.5) = 0.2.$$

若直接比较观测组均值，Bayes 公式给出

$$\mathbb{P}(X = 1 | T = 1) = 0.8, \quad \mathbb{P}(X = 1 | T = 0) = 0.2.$$

结合一致性与交换性，

$$\mathbb{E}[Y | T = 1] = 0.8 \times 0.7 + 0.2 \times 0.3 = 0.62,$$

$$\mathbb{E}[Y | T = 0] = 0.2 \times 0.5 + 0.8 \times 0.1 = 0.18.$$

观测均值差为 0.44，明显大于真实 ATE 0.2。差异来自处理组包含更多高风险者，而不是处理效应在计算中突然增大。

按式 (12.14) 在每个风险层内先比较，再按目标总体的 X 分布平均，便恢复 0.2。这个算例同时显示三项条件的职责：一致性把各组观察结果连接到相应潜在结果，交换性使同一风险层中的两组可比，重叠保证每层都有两种处理。若遗漏了未记录的病情严重程度，交换性可能失败；若 $e(1) = 1$,

高风险层的未处理结果便没有观测参照。更灵活的预测模型只能降低已识别表达式的拟合误差，不能消除这两类问题。

12.4 部分识别与敏感性分析

12.4.1 识别集合保留所有相容答案

点识别要求所有允许机制给出同一个目标值。若观测分布和当前假设只把目标限制在一个集合内，就得到**部分识别**（partial identification）。设 $\mathcal{M}(P_{\text{obs}})$ 为与观测分布及已声明假设相容的机制集合，目标泛函为 $\tau(M)$ 。其**识别集合**（identified set）定义为

$$\mathcal{I}(P_{\text{obs}}) = \{\tau(M) : M \in \mathcal{M}(P_{\text{obs}})\}. \quad (12.17)$$

一般识别集合不必是单个区间，也可能由彼此分离的点或区间组成。它的下确界与上确界只确定最小的区间包络，不能证明包络中的每个值都由相容机制达到。下文只有在能够说明中间值可达时，才把上下界之间的整个区间视为识别集合；否则只报告上下界。区间包络的宽度可以概括信息与假设留下的总体歧义，但不能替代集合本身。增加样本可以更精确地估计 P_{obs} ，却不一定使 $\mathcal{I}$ 缩成一点。

12.4.2 仅凭有界结果得到的效应界

先假设二元处理，并且对每个 $t \in \{0, 1\}$ 都有 $0 \leq Y(t) \leq 1$ 几乎处处成立；一致性使观测结果也继承这一范围。以下只采用一致性，不假设交换性。处理下的平均潜在结果可分解为

$$\begin{aligned} \mathbb{E}[Y(1)] &= \mathbb{E}[TY(1)] + \mathbb{E}[(1 - T)Y(1)] \\ &= \mathbb{E}[TY] + \mathbb{E}[(1 - T)Y(1)]. \end{aligned}$$

第二项对应未处理者若接受处理会怎样，数据没有观察到它。由 $0 \leq Y(1) \leq 1$,

$$0 \leq \mathbb{E}[(1 - T)Y(1)] \leq \mathbb{P}(T = 0),$$

所以

$$\mathbb{E}[TY] \leq \mathbb{E}[Y(1)] \leq \mathbb{E}[TY] + \mathbb{P}(T = 0). \quad (12.18)$$

同理,

$$\mathbb{E}[(1 - T)Y] \leq \mathbb{E}[Y(0)] \leq \mathbb{E}[(1 - T)Y] + \mathbb{P}(T = 1). \quad (12.19)$$

用第一个区间下端减第二个区间上端得到 ATE 下界，反向组合得到上界：

$$\begin{aligned} \mathbb{E}[TY] - \mathbb{E}[(1-T)Y] - \mathbb{P}(T=1) \leq \tau \leq \mathbb{E}[TY] + \mathbb{P}(T=0) \\ - \mathbb{E}[(1-T)Y]. \end{aligned} \quad (12.20)$$

这组界可能很宽，但每个端点都有明确依据，而且在当前不受其他限制的机制类中是 **锐界** (sharp bounds)。要达到 ATE 下界，可令所有未处理者的缺失结果 $Y(1) = 0$ ，并令所有已处理者的缺失结果 $Y(0) = 1$ ；要达到上界，则分别令这两类缺失结果为 1 和 0。这些赋值不改变任何已观察结果，并分别达到式 (12.20) 的两个端点。对端点构造作随机混合还能得到中间值，所以该宽度不是推导松弛造成的。若再要求单调性、函数平滑或特定联合结构，这些端点可能不再可达，锐界必须相对于缩小后的模型类重新计算。用处理组均值差替代这组界，相当于偷偷加入交换性，而不是让结论更精确。

12.4.3 支持缺口怎样进入总体效应

现在假设条件交换性在概念上可信，但重叠只在协变量区域 $\mathcal{O}$ 成立。令 $\mathcal{U}$ 为目标总体中缺少某种处理的区域，并设 $\mathcal{O} \cup \mathcal{U}$ 覆盖目标总体。继续假设对所有 $t \in \{0, 1\}$ 都有 $0 \leq Y(t) \leq 1$ 几乎处处成立，则条件效应

$$\tau(x) = \mathbb{E}[Y(1) - Y(0) \mid X = x]$$

总在 $[-1, 1]$ 内。在 $\mathcal{O}$ 上用调整公式识别它，在 $\mathcal{U}$ 上只保留范围，于是

$$\begin{aligned} \mathbb{E}[\tau(X) \mathbb{I}\{X \in \mathcal{O}\}] - \mathbb{P}(X \in \mathcal{U}) \leq \tau \\ \leq \mathbb{E}[\tau(X) \mathbb{I}\{X \in \mathcal{O}\}] + \mathbb{P}(X \in \mathcal{U}). \end{aligned} \quad (12.21)$$

缺口人群占比越大，最坏范围越宽。若愿意把目标总体限制到 $\mathcal{O}$ ，可以点识别重叠人群效应，但它已不是原总体 ATE。若假设缺口区域的效应与邻近区域平滑、同号或有已知范围，界可以收紧；这些都是新增外推假设，不能由重叠区域的拟合优度证明。

12.4.4 覆盖缺口怎样限制策略价值

同一分解可以直接用于单步策略评价。令有限动作集合为 $\mathcal{A}$ ，日志策略的动作概率为 $e_a(x) = \mathbb{P}(T = a \mid X = x)$ ，目标策略为 $\pi(a \mid x)$ 。假设对所有 $a \in \mathcal{A}$ 都有 $L \leq Y(a) \leq H$ 几乎处处成立；一致性使观测结果也满足同一范围。目标策略价值定义为按 π 重新分配动作后的平均结果

$$V(\pi) = \mathbb{E}_X \left[\sum_{a \in \mathcal{A}} \pi(a \mid X) \mathbb{E}[Y(a) \mid X] \right].$$

在一致性、给定 X 的交换性以及 $\pi(a | x) > 0 \implies e_a(x) > 0$ 成立时,

$$\begin{aligned}\mathbb{E}\left[\frac{\pi(T | X)}{e_T(X)}Y \middle| X\right] &= \sum_{\substack{a \in \mathcal{A} \\ e_a(X) > 0}} e_a(X) \frac{\pi(a | X)}{e_a(X)} \mathbb{E}[Y | T = a, X] \\ &= \sum_{a \in \mathcal{A}} \pi(a | X) \mathbb{E}[Y(a) | X].\end{aligned}$$

对 X 再取期望, 便得到

$$V(\pi) = \mathbb{E}\left[\frac{\pi(T | X)}{e_T(X)}Y\right]. \quad (12.22)$$

这正是换测度在因果目标上的使用: 权重改变动作分配, 却保留给定背景和动作的结果机制。等式中的随机权重只在日志实际可能选择的动作上求值; 目标策略在其余动作上的概率由覆盖条件强制为零, 因而没有 0/0 的约定。

若覆盖条件失败, 定义目标策略落在缺口上的概率质量

$$r = \mathbb{E}_X \left[\sum_{a: e_a(X)=0} \pi(a | X) \right],$$

并记已覆盖部分能够识别的贡献为

$$K = \mathbb{E}_X \left[\sum_{a: e_a(X) > 0} \pi(a | X) \mathbb{E}[Y | T = a, X] \right].$$

缺口部分只能贡献 $[Lr, Hr]$, 从而

$$K + Lr \leq V(\pi) \leq K + Hr. \quad (12.23)$$

两个策略各自的价值上下界若分离, 现有信息仍足以确定其排序; 若相应范围重叠, 单独比较这两组边际上下界不足以判断排序。此时应直接研究 $V(\pi_1) - V(\pi_2)$ 的联合识别集合或上下界, 因为两个策略共享同一组未知潜在结果, 不能把它们的边际范围当作彼此独立。无论如何, 都不能把某个拟合器的单一外推当作排序证据。这里讨论的是单步行动。第 17.3 节建立序贯策略与状态价值后, 还要逐时刻检查历史覆盖、时间变化的混杂和轨迹结果定义, 不能把式 (12.22) 直接套到整条轨迹。

12.4.5 线性混杂与潜在结果偏差函数

未观测混杂留下的歧义可以用敏感性参数表达, 而不必在“完全无混杂”和“完全不可知”之间二选一。一个最小线性例子先显示偏差从哪里进入。

设变量已经中心化, 并令

$$T = \alpha U + \varepsilon_T, \quad Y = \beta T + \gamma U + \varepsilon_Y,$$

其中 $U, \varepsilon_T, \varepsilon_Y$ 两两独立、方差有限, 且 $\text{Var}(T) > 0$ 。把 Y 仅对 T 作总体线性回归, 观测斜率为

$$\beta_{\text{obs}} = \frac{\text{Cov}(T, Y)}{\text{Var}(T)} = \beta + \gamma \frac{\alpha \text{Var}(U)}{\text{Var}(T)}. \quad (12.24)$$

β 是该结构模型中的处理系数, 后一项是共同原因同时进入处理和结果造成的混杂偏差。若领域信息只支持该偏差的绝对值不超过 Λ , 则 $\beta \in [\beta_{\text{obs}} - \Lambda, \beta_{\text{obs}} + \Lambda]$ 。数据可估计 β_{obs} , 却不能在额外信息时把 α, γ 各自分开; 改变函数形式也会改变这个敏感性参数的含义。

对非线性和异质效应, 不存在一个普遍通用的斜率修正量。仍记

$$\mu_t(x) = \mathbb{E}[Y \mid T = t, X = x], \quad e(x) = \mathbb{P}(T = 1 \mid X = x).$$

对目标总体中满足 $0 < e(x) < 1$ 且下列条件期望有限的 x , 定义两个选择偏差函数

$$b_1(x) = \mathbb{E}[Y(1) \mid T = 1, X = x] - \mathbb{E}[Y(1) \mid T = 0, X = x],$$

$$b_0(x) = \mathbb{E}[Y(0) \mid T = 1, X = x] - \mathbb{E}[Y(0) \mid T = 0, X = x].$$

完整条件交换性 (12.11) 蕴含 $b_1(x) = b_0(x) = 0$ 。对本节的平均效应目标, 后一个条件表达的是较弱的条件均值交换性; 它不能反推出两个处理组中的潜在结果完整条件分布相同。若要对目标总体平均, 上述重叠和有限期望条件还须对目标总体中的 x 几乎处处成立。一致性给出 $\mathbb{E}[Y(1) \mid T = 1, X = x] = \mu_1(x)$, 因而

$$\begin{aligned} \mathbb{E}[Y(1) \mid X = x] &= e(x)\mu_1(x) + (1 - e(x))(\mu_1(x) - b_1(x)) \\ &= \mu_1(x) - (1 - e(x))b_1(x). \end{aligned}$$

同理,

$$\mathbb{E}[Y(0) \mid X = x] = \mu_0(x) + e(x)b_0(x).$$

所以条件效应满足

$$\tau(x) = \mu_1(x) - \mu_0(x) - (1 - e(x))b_1(x) - e(x)b_0(x). \quad (12.25)$$

若领域知识只支持

$$|b_1(x)| \leq \Gamma_1(x), \quad |b_0(x)| \leq \Gamma_0(x),$$

则由三角不等式,

$$\mu_1(x) - \mu_0(x) - \Delta(x) \leq \tau(x) \leq \mu_1(x) - \mu_0(x) + \Delta(x), \quad (12.26)$$

其中

$$\Delta(x) = (1 - e(x))\Gamma_1(x) + e(x)\Gamma_0(x).$$

对 X 取平均便得到 ATE 的敏感性区间。这里的 Γ_t 不是由观测数据自动估计出的误差条, 而是对未观测选择差异强度的假设。敏感性分析应展示结论在多大 Γ_t 下改变符号或越过决策阈值, 而不是只报告一个方便的参数值。

12.4.6 额外假设怎样收紧集合

若有理由相信处理对每个单位都不会降低结果, 即

$$Y(1) \geq Y(0),$$

则 ATE 至少为零, 可以把任何已有下界提高到零。这项**单调性** (monotonicity) 排除了受处理伤害的机制; 它比“平均上看有益”更强。若只知道处理效应位于 $[-\rho, \rho]$, 则支持缺口中的 $[-1, 1]$ 可替换为更窄范围。

跨环境信息也可能收紧识别集合。例如一个环境提供随机试验, 另一个环境只提供目标总体协变量分布; 若条件处理效应在两环境间保持不变, 并且协变量支持得到覆盖, 就能把试验效应重新加权到目标环境。机制不变、总体可比和支持覆盖分别是新增假设。仅观察到某个预测关系在多个环境都稳定, 不足以排除共同隐藏原因、选择机制或多个机制恰好同时变化。

识别集合及其区间包络还必须与**置信区间**区分。前者在总体分布已知时仍可能不是单点, 表达机制歧义; 后者由有限样本产生, 表达对总体量、识别集合或其端点的估计误差。实际报告可以给出端点的置信范围, 但不能把包络宽度与抽样误差合并后统一称为“模型不确定性”, 否则读者无法判断增加样本、改变设计或增加假设中的哪一种能够收紧结论。

12.5 反事实与行动补救

12.5.1 反事实需要固定同一个体的背景

总体干预分布重新从外生背景总体中抽取个体, 回答“若所有人采用处理 t , 平均会怎样”。**反事实** (counterfactual) 则以已经观察到的个体为条件, 回答“这个人在另一种处理下会怎样”。在 SCM 中, 标准计算包含三个步骤:

1. 根据实际观测更新外生背景 U 的条件分布;
2. 用目标行动替换相应结构方程;
3. 在同一个背景分布下运行修改后的方程并计算结果。

这三个步骤常称为背景推断、行动和预测。关键是实际世界与反事实世界共享同一外生背景;若重新抽取一个人,计算的便是干预总体而不是个体反事实。

这三步可以统一写成分布推前。设无环 SCM 在自然机制下的解映射为 $V = F(U)$, 事实证据为 $E = e$, 行动 a 替换若干结构方程后得到解映射 F^a 。若所在空间允许选取正则条件分布 $P_{U|E=e}$, 则对任意可测集合 B ,

$$\begin{aligned}\mathbb{P}(V_a \in B \mid E = e) &= (F^a_{\#} P_{U|E=e})(B) \\ &= \int \mathbb{I}\{F^a(u) \in B\} P_{U|E=e}(du).\end{aligned}\quad (12.27)$$

其中 $F^a_{\#}P$ 表示把分布 P 经映射 F^a 推前。第一步由事实证据更新背景分布, 第二步只改变映射, 第三步把同一个背景后验推到反事实结果空间。连续证据点通常概率为零, 此时等式按正则条件分布的版本理解, 并只对证据分布几乎处处的 e 有定义。

考虑教学模型

$$X = U_X, \quad T = f_T(X, U_T), \quad Y = 2X + 3T + U_Y. \quad (12.28)$$

某人实际观测为 $X = 2, T = 0, Y = 5$ 。由结果方程反推出 $U_Y = 5 - 2 \times 2 - 3 \times 0 = 1$ 。若保持该人的 X, U_Y 不变, 把处理设为 1, 则

$$Y_{T \leftarrow 1} = 2 \times 2 + 3 \times 1 + 1 = 8.$$

差值 3 来自该结构方程中处理的直接作用。若结果方程或 U_Y 不能由观测唯一确定, 反事实结果应是条件分布或取值范围, 而不是强行给出 8 这样的点值。

示例 12.2 两点背景后验的反事实推前 令背景变量 $U \in \{u_L, u_H\}$ 的先验概率各为 $1/2$ 。事实世界观察到二元信号 $S = 1$, 且

$$\mathbb{P}(S = 1 \mid U = u_H) = \frac{3}{4}, \quad \mathbb{P}(S = 1 \mid U = u_L) = \frac{1}{4}.$$

Bayes 公式给出

$$\mathbb{P}(U = u_H \mid S = 1) = \frac{3}{4}, \quad \mathbb{P}(U = u_L \mid S = 1) = \frac{1}{4}.$$

设行动 a 下的结果映射满足 $F_Y^a(u_L) = 2$ 与 $F_Y^a(u_H) = 6$ 。式 (12.27) 于是给出

$$\mathcal{L}(Y_a | S = 1) = \frac{1}{4}\delta_2 + \frac{3}{4}\delta_6, \quad \mathbb{E}[Y_a | S = 1] = 5.$$

若忽略事实信号并从背景先验重新抽取个体，干预总体分布则是 $\frac{1}{2}\delta_2 + \frac{1}{2}\delta_6$ ，均值为 4。两个答案使用同一行动映射，差别只在于反事实保留了由事实证据得到的背景后验。

12.5.2 干预边缘不能确定跨世界配对

即使随机试验分别识别了 $Y(0)$ 和 $Y(1)$ 的边缘分布，也未必识别它们怎样在同一个个体的配对。设两种干预下的结果都服从 Bernoulli(1/2)。模型甲让一半单位满足 $(Y(0), Y(1)) = (0, 0)$ ，另一半满足 $(1, 1)$ ；模型乙让两类单位分别满足 $(0, 1)$ 和 $(1, 0)$ 。两者在每种处理下都产生相同的结果分布，ATE 也都为零，但模型甲的个体效应恒为零，模型乙的个体效应则分别为 1 和 -1。

两套配对机制连完整随机试验的两组边缘分布也无法区分。若要回答“事实结果为零的这个单位在另一处理下会怎样”，还需要跨世界联合结构、重复干预、机制限制或相应的部分识别。这一区别说明，干预分布的点识别不会自动传递给条件个体反事实。

12.5.3 改变模型输入不等于改变现实因素

对一个预测器 $\hat{y} = f(\mathbf{x})$ ，把输入字段 t 从 0 改成 1 并重新计算，只得到

$$f(\mathbf{x}, t = 1) - f(\mathbf{x}, t = 0).$$

它描述已训练函数对输入替换的响应。现实行动还可能改变处理的后继变量，并受到资源、时间和可行域约束。若培训会提高技能，又减少当期工作时间，只修改“是否培训”一列而把技能和时间固定，通常不是任何可实现世界。

行动补救 (algorithmic recourse) 寻找能够改善不利决策的可行行动。因果补救需要在结构模型中施加行动，让所有后继变量按机制共同变化，再把新状态送入决策系统。若事实证据唯一确定了外生背景 $\mathbf{u}$ ，其优化形式可以写成

$$\min_{a \in \mathcal{A}(\mathbf{x})} c(a; \mathbf{x}) \quad \text{使得} \quad d(\mathbf{V}_a(\mathbf{u})) \text{达到目标结果}, \quad (12.29)$$

其中 $\mathcal{A}(x)$ 是该个体可实施的行动集合, c 是行动成本, $V_a(u)$ 是同一背景下干预后的状态, d 是最终决策规则。低输入距离不等于低行动成本, 不可改变属性也不应被当作建议。

事实证据通常只给出背景后验 $P_{U|E=e}$, 此时对某个候选 u 成功并不保证行动对该个体可靠。给定可容许失败概率 $\alpha \in [0, 1]$, 一种概率型目标是要求

$$\mathbb{P}(d(V_a(U)) \text{ 达到目标结果} \mid E = e) \geq 1 - \alpha.$$

若要求稳健保证, 则可进一步要求后验支持中的每个背景都达到目标。概率约束与最坏情形约束利用的是同一个背景后验, 但后者更保守; 二者都比只选一个候选背景检验行动更强。

补救还具有时间和策略边界。多人同时采取建议可能改变价格、名额或审核规则; 决策系统更新后, 旧补救未必仍有效; 执行成本与成功概率也可能因群体而异。因此, 找到一个能翻转当前模型输出的邻近输入, 只证明了当前预测边界的局部性质, 不自动证明建议可行、持久或公平。

12.5.4 反事实公平与不可识别性

反事实公平比较同一个外生背景下, 改变受保护属性后预测分布是否保持。设受保护属性为 A , 实际观测为 $(X = x, A = a)$ 。一种表达要求对允许的 a' 和预测值集合 B ,

$$\mathbb{P}(\hat{Y}_{A \leftarrow a} \in B \mid X = x, A = a) = \mathbb{P}(\hat{Y}_{A \leftarrow a'} \in B \mid X = x, A = a). \quad (12.30)$$

实际观测用于推断背景, 随后两个世界共享该背景。只在数据表中替换 A , 同时固定所有由 A 产生的后继变量, 检验的是不同对象。

个体反事实通常比平均干预效应需要更强结构。第 12.1 节的两套模型观测分布相同, 却对 $T \leftarrow 1$ 给出不同后果; 即使某些平均效应通过额外设计得到识别, 同一个体的 $(Y(0), Y(1))$ 联合关系仍可能没有被确定。若多个 SCM 都与观测和试验结果相容, 应在这些模型上报告反事实或补救结论的范围。一个生成模型能够产出清晰的“另一世界”样本, 只说明它选定了一套机制, 不说明该机制已由数据唯一识别。

12.6 结构发现与假设检验

12.6.1 Markov 性、忠实性与三点结构

定义 12.1 和因果 Markov 性允许从图推出条件独立。结构发现要反向利用观测独立性排除候选图, 因此还要限制那些由参数巧合产生、却不对应路径阻断的独立关系。

反向推断还需要**忠实性** (faithfulness)。它要求分布中出现的条件独立都由图结构解释，而不是由特殊参数抵消、确定性约束或误差相关偶然产生。因果 Markov 性说明图蕴含哪些独立性，忠实性允许从观察到的独立性反推图上缺少哪些连接。前者不自动推出后者。

回看图 12.1, 面板 (a) 的共同原因和面板 (b) 的中介链在给定中间节点后都会关闭；把中介链的两条箭头同时反向，这一条件独立模式也不变。因此，忽略节点名称后的三种结构 $X \rightarrow Z \rightarrow Y$ 、 $X \leftarrow Z \leftarrow Y$ 和 $X \leftarrow Z \rightarrow Y$ 都蕴含

$$X \perp Y \mid Z,$$

并且一般不蕴含 $X \perp Y$ 。仅靠这些条件独立关系，无法判断中间变量是传递作用还是共同原因。相反，面板 (c) 的碰撞结构通常蕴含 $X \perp Y$ ，而给定中间节点后可能相关，所以可以由不同的独立模式与前三者区分。

12.6.2 Markov 等价类是观测结构的自然输出

若同一节点集上的两张有向无环图具有完全相同的 d-分离关系，就称它们 **Markov 等价** (Markov equivalent)；与给定图 Markov 等价的全部有向无环图组成它的 **Markov 等价类** (Markov equivalence class, MEC)。两张图 Markov 等价，当且仅当它们具有相同的**骨架** (skeleton)，即忽略方向后有相同的邻接边，并且具有相同的**无屏蔽碰撞结构** (unshielded collider)：形如 $X \rightarrow Z \leftarrow Y$ ，且 X 与 Y 不相邻³。因而，在因果 Markov 性与忠实性等假设下，纯观测条件独立信息通常只能识别一个 Markov 等价类，而不是唯一有向图。

³ J. Pearl, *Probabilistic Reasoning in Intelligent Systems: Networks of Plausible Inference*, Morgan Kaufmann, 1988

局部差异已经由图 12.1 展示：链和共同原因具有相同骨架，且都没有无屏蔽碰撞点；碰撞结构则改变了条件化前后的连通模式。对较大图，还要像图 12.2 那样检查全部路径，而不能只比较一个三点片段。相同骨架且没有新增无屏蔽碰撞点的方向变化，才可能留在同一个等价类中。

这个刻画可以从路径阻断的两类关键信息理解。若两图骨架不同，某对节点在一图中直接相邻，另一图却需要经过中间节点，后者可能出现前者没有的分离关系。若骨架相同但某个无屏蔽三点结构只在一图中是碰撞点，那么两端节点在不给定中点与给定中点时的连通模式会相反，两图也不可能编码同一组 d-分离。这说明相同骨架和无屏蔽碰撞点是必要条件。

充分性需要控制较长路径。一条边 $X \rightarrow Y$ 若满足 $\text{pa}(Y) = \text{pa}(X) \cup \{X\}$ ，称为**覆盖边** (covered edge)；反转这条边不会产生新的无屏蔽碰撞点，并可保持无环。相应的两个局部因子可由

$$p(x \mid \text{pa}(X))p(y \mid x, \text{pa}(X)) = p(y \mid \text{pa}(X))p(x \mid y, \text{pa}(X))$$

重新表示，所以这次反转保持同一组 Markov 分布与 d-分离关系。证明的

剩余步骤是说明，具有相同骨架和无屏蔽碰撞点的两张 DAG 可以通过一系列覆盖边反转相互到达。这个构造处理了长路径上的方向变化，也解释了为什么刻画只需记录骨架与无屏蔽碰撞点。

等价类可以用部分有向图表示：在所有等价图中方向一致的边保留箭头，方向仍可变化的边保持无向。算法输出这种等价类不是“尚未优化好”，而是忠实、无环且无潜在混杂等假设下观测分布本身留下的总体歧义。增加同一观测分布的样本，只会更准确地判断独立关系，不会为等价类内部凭空增加方向信息。

12.6.3 潜在混杂、选择与有限样本检验

若所有变量的共同原因都已观测，就称满足因果充分性。潜在共同原因会使两个可观测节点相关，却无法由其中一方向另一方的箭头正确表示。允许潜在混杂时，结构发现的输出通常要扩展为带不同端点标记的部分图，用来区分确定的祖先关系、可能方向和无法排除的隐藏共同原因。测量误差和按碰撞点选择样本也会改变条件独立模式，不能简单解释为新因果边。

总体条件独立在有限样本中还要通过检验或评分近似判断。以 $H_0 : V_i \perp V_j \mid \mathbf{V}_S$ 为原假设，并假定约束型算法在未拒绝条件独立时删除候选边：第一类错误把真实独立误判为依赖，可能保留虚假边；第二类错误把实际依赖误判为独立，可能删除真实边。后续搜索和定向规则还可能传播这些错误，而评分型算法未必能直接套用这一对应。高维条件集合又使每个分层中的有效样本减少，接近零但非零的依赖尤其难与独立区分。结构学习的一致性结论需要同时说明真实分布的 Markov 与忠实条件、检验或评分随样本增长的性质、候选图范围及搜索是否足以找到目标。算法返回一张确定图，不代表方向的不确定性已经消失。

12.6.4 干预与跨环境信息提供额外方向证据

干预会切断目标变量原有的进入机制。若在观察数据中 X 与 Y 相关，而随机设置 X 后 Y 的分布随设置值改变，这为 X 位于 Y 上游提供了观测关联之外的证据。对不同节点实施干预可以缩小 Markov 等价类；若干预目标未知、执行不完全或干预同时改变其他机制，则必须把这些不确定性纳入模型。

跨环境信息也能提供约束。若不同环境只改变少数外生分布，而某个条件机制保持不变，机制不变性可以帮助比较候选方向。但“关系稳定”单独不是充分条件。隐藏共同原因可能在所有已观察环境中都稳定，环境变化也可能太弱而没有打破错误方向；选择规则若同步变化，还可能制造新的稳定关联。应明确哪些机制允许变化、环境标签是否影响结果，以及稳定性是作为假设、检验对象还是经验线索使用。

结构发现因而需要多类证据协作。条件独立限制观测等价类，受控干预主动打破部分歧义，机制知识排除不合理方向，敏感性分析检查结论对潜在混杂、弱依赖和选择机制的变化。这些证据可以互相补充，却不能由一项代理另一项。对于反馈环、随时间变化的机制或处理定义不稳定的系统，无环静态 SCM 本身也可能不适用，需要改用动态或循环因果模型并重新定义干预。

12.7 本章小结

观测分布描述自然机制运行时变量怎样共同出现，干预分布描述替换某个生成机制后的总体结果，个体反事实则在实际观测推断出的同一背景下比较另一行动。两套结构机制可以拥有完全相同的观测分布，却给出不同干预和反事实；这说明预测精度、样本规模和优化能力都不能代替生成假设。

潜在结果把不同处理下的结果并列表示，一致性连接实际处理与观察结果，无干扰和处理版本唯一性保证目标定义清楚。随机分配直接建立交换性；观察研究则通常需要条件交换性与支持重叠。正值性只需覆盖目标总体中目标行动会使用的协变量-行动组合，不要求目标之外处处重叠。结合这些条件，调整公式和逆概率表示把 ATE 化成可观测分布的泛函。识别只说明总体目标能否唯一确定，有限样本估计和数值计算还需各自的误差条件。

当交换性、重叠或机制知识不足时，部分识别保留所有相容答案。有界结果给出不依赖无混杂的锐界，支持缺口按缺口人群或目标策略未覆盖的概率质量扩大范围，偏差函数把未观测混杂的强度转成敏感性区间。单调性、效应范围或跨环境机制不变可以收紧集合，但每项收紧都来自新增假设。一般识别集合未必是区间，上下界只给出它的区间包络；识别集合表达总体机制歧义，置信区间表达有限样本误差，二者不能混为同一种不确定性。

结构发现同样受识别边界约束。因果 Markov 性把图结构连接到条件独立，忠实性才允许从独立关系反推结构；纯观测数据通常只能确定 Markov 等价类，潜在混杂、选择和测量误差还会扩大歧义。干预、跨环境变化和机制知识能够补充方向证据，但必须写清各自保持和改变了什么。因此，因果推断的核心不是为关联加上箭头，而是对每个干预、效应或反事实结论列明目标、生成假设、可用证据和仍未被决定的范围。下一部分从有限候选与约束开始；第 13 章将把变量关系暂时放回纯离散对象，区分计数、可行性、最优性与计算复杂度，第 14 章再系统处理路径、分离与图分解。第 17 章把单步干预扩展为序贯行动和价值递推；第二卷“基础、理论和可信性”的“公平性”章与第二卷“基础、理论和可信性”的“可解释性”章则分别回用反事实目标和行动补救，并重新加入规范要求与实际验证条件。

第四部分

离散数学与图论

Discrete Mathematics and Graph Theory

第 13 章

组合数学

第 3 部分用分布描述不确定结果，但许多学习问题还要求从有限候选中作出选择。标签是否启用、规则是否满足、特征是否保留，最终都可写成有限个离散变量的赋值。候选有限只保证可以逐个列出，并不说明候选数量可以承受，也不说明每个候选都符合规则，更不说明最优候选能在可接受的时间内找到。要区分这些问题，需要分别研究计数、约束、目标结构和计算资源。

本章沿用同一组二值变量。令

$$V = \{1, \dots, n\}, \quad \mathbf{z} = (z_i)_{i \in V} \in \{0, 1\}^n, \quad S(\mathbf{z}) = \{i \in V : z_i = 1\}.$$

$z_i = 1$ 表示选择第 i 个候选，集合 $S(\mathbf{z})$ 记录完整选择。贯穿各节的小例子取 $V_0 = \{1, 2, 3, 4\}$ ：候选 1 与 2 这两种基础标签必须恰选一个，候选 3 依赖候选 1，候选 4 则要求候选 2 或 3 至少出现一个。计数回答可能有多少个 S ，逻辑规则从中筛出可行集合，集合函数比较这些可行集合，而计算理论追问相应程序能否停机以及资源怎样随输入增长。变量之间的关系怎样支持局部计算，将由第 14 章继续讨论。

13.1 集合族与组合计数

13.1.1 子集族把允许的候选组织起来

第 1 章已经给出幂集与组合数。这里关心的不是孤立的计数公式，而是限制改变后候选规模怎样变化。一个**集合族** (set family) $\mathcal{F} \subseteq \mathcal{P}(V)$ 是一组允许讨论的子集。若不加任何限制， $\mathcal{F} = \mathcal{P}(V)$ ；每个元素独立地选择或不选择，所以

$$|\mathcal{P}(V)| = 2^n. \quad (13.1)$$

这个结论也可由二项式定理得到： $\sum_{k=0}^n \binom{n}{k} = (1+1)^n = 2^n$ 。两种证明分别强调二值赋值与按集合大小分层，它们计算的是同一批对象。

同样是从 n 个不同元素中取出 k 个，是否记录顺序会改变计数对象。若

依次填入 k 个位置, 其中 $0 \leq k \leq n$, 每个位置不能重复使用元素, 方案数为

$$n(n-1)\cdots(n-k+1) = \frac{n!}{(n-k)!}.$$

若只记录被选中的子集, 每个 k 元子集会被它的 $k!$ 种排列重复表示, 因而方案数为 $\binom{n}{k} = n!/[k!(n-k)!]$. 例如从 $\{1, 2, 3, 4\}$ 中取两个元素, 有 12 个有序对, 却只有 6 个二元子集; $(1, 3)$ 与 $(3, 1)$ 在前一个问题中不同, 在后一个问题中表示同一个选择. 计数公式必须随“什么结果算作同一个”一起给出.

每个 $S \subseteq V$ 也确定一个有序二分划分 $(S, V \setminus S)$, 所以有序二分划分仍有 2^n 个. 若两部分没有名称, $(S, V \setminus S)$ 与 $(V \setminus S, S)$ 表示同一个划分; 当 $n \geq 1$ 时没有子集等于自己的补集, 每个无序划分恰被计算两次, 数量为 2^{n-1} . 是否区分两侧决定了计数对象, 不能只看它们都把 V 分成两部分. 这里允许某一部分为空; 若要求两部分都非空, 有序与无序数量应分别减为 $2^n - 2$ 与 $2^{n-1} - 1$. 当 $n = 0$ 时, 交换两侧不会产生两个不同表示, 上述除以 2 的论证也不适用.

若只允许恰好选择 k 项, 集合族变为

$$\binom{V}{k} = \{S \subseteq V : |S| = k\}, \quad \left| \binom{V}{k} \right| = \binom{n}{k}.$$

若允许至多选择 k 项, 则数量为 $\sum_{j=0}^k \binom{n}{j}$. 因此“候选总数有限”仍可能掩盖完全不同的增长规模: 固定 k 时, 该和关于 n 至多按 n^k 增长; k 随 n 线性增长时, 候选数却可能接近 2^n .

计数常可通过一个变量把问题拆成两个较小问题. 记 $a_{n,k}$ 为从 n 个元素中选择 k 个的方案数. 对 $n \geq 1$, 固定元素 n 后, 所有方案被不重不漏地分成“不含 n ”与“含 n ”两类. 为使边界项也有定义, 约定 $a_{0,0} = 1$, 并在 $k < 0$ 或 $k > n$ 时令 $a_{n,k} = 0$. 于是对 $n \geq 1$ 和任意整数 k 都有

$$a_{n,k} = a_{n-1,k} + a_{n-1,k-1}. \quad (13.2)$$

这既是 Pascal 恒等式, 也是一个递推算法. 若只保存上一行, 计算全部 $a_{n,0}, \dots, a_{n,n}$ 需要 $O(n^2)$ 次加法和 $O(n)$ 个存储单元. 闭式公式、递推关系和计算过程由此承担不同作用: 闭式便于分析规模, 递推揭示分组结构, 算法还必须说明求值顺序和资源.

13.1.2 二值标记的组合计数

第 4 章式 (4.23) 已经定义增长函数, 并用有限输入上的限制来刻画二值函数类的组合丰富度. 这里把每种标记改写成子集, 以便直接使用本节

的计数方法。给定输入 $x_1, \dots, x_m$ 和二值函数类 $\mathcal{H}$, 每个 $h \in \mathcal{H}$ 确定

$$A_h = \{i \in \{1, \dots, m\} : h(x_i) = 1\}.$$

函数在这组输入上的标记向量与 A_h 一一对应, 因此不同标记的数量就是集合族 $\{A_h : h \in \mathcal{H}\} \subseteq \mathcal{P}(\{1, \dots, m\})$ 的大小。式 (13.1) 随即给出上界 2^m ; 增长函数只是在所有输入组中取这个数量的上确界。

这个表示还能直接计算受基数约束的函数族。令 $\mathcal{X}$ 为无限集, 固定 $k \geq 0$, 并设

$$\mathcal{H}_k = \{h_S : S \subseteq \mathcal{X}, |S| \leq k\}, \quad h_S(x) = \mathbb{I}\{x \in S\}.$$

对 m 个互异输入, $\mathcal{H}_k$ 能够实现的正类索引集合恰是所有大小不超过 k 的子集, 因而

$$\Pi_{\mathcal{H}_k}(m) = \sum_{j=0}^{\min\{k, m\}} \binom{m}{j}.$$

固定 k 时, 这个数量关于 m 至多按 m^k 增长; 当 $k \geq m$ 时, 它恢复为 2^m 。同一个幂集计数由此区分出多项式规模与指数规模。它仍只描述有限输入上的模式数, 不直接给出统计误差界, 也不保证能够高效找到实现某种标记的函数。

一个可逐项复核的例子是实数轴上的区间分类器。令 $x_1 < \dots < x_m$ 互异, 函数 $h_{a,b}(x) = \mathbb{I}\{a \leq x \leq b\}$ 把落在某个闭区间内的输入标为 1。非空正类索引必为连续块 $\{i, i+1, \dots, j\}$, 这样的块由 $1 \leq i \leq j \leq m$ 唯一确定; 再加上空正类, 可实现模式数恰为

$$1 + \sum_{i=1}^m (m - i + 1) = 1 + \frac{m(m+1)}{2}.$$

当 $m = 3$ 时, 七个模式为 000, 100, 010, 001, 110, 011, 111, 只有 101 无法实现。因此三个有序点不能被该函数类打散; 两个点的四种模式都能实现。这个算例也说明, 参数 a, b 取值无限多, 并不意味着有限输入上的标记模式也有无限多个。

13.1.3 容斥原理校正重复计数

直接把若干坏情形的数量相加会重复计算同时违反多条规则的赋值。**容斥原理** (inclusion-exclusion principle) 用交集项逐层校正这种重复。

定理 13.1 有限容斥原理 设 $A_1, \dots, A_m$ 是有限集合。则

$$\left| \bigcup_{i=1}^m A_i \right| = \sum_{\emptyset \neq I \subseteq \{1, \dots, m\}} (-1)^{|I|+1} \left| \bigcap_{i \in I} A_i \right|. \quad (13.3)$$

证明. 固定任意元素 x , 设它恰好属于 r 个集合。若 $r = 0$, 它在等式两侧都没有贡献。若 $r \geq 1$, 右侧从含有 x 的 r 个集合中选择非空索引集, 给 x 计算的总系数为

$$\sum_{k=1}^r (-1)^{k+1} \binom{r}{k} = 1 - \sum_{k=0}^r (-1)^k \binom{r}{k} = 1 - (1-1)^r = 1.$$

所以并集中的每个元素在右侧恰好被计算一次, 对所有 x 求和即得结论。 ■

回到 V_0 上的四个变量。把三条规则的违反事件记为

$$\begin{aligned} A_1 &= \{\mathbf{z} : z_1 = z_2\}, \\ A_2 &= \{\mathbf{z} : z_3 = 1, z_1 = 0\}, \\ A_3 &= \{\mathbf{z} : z_4 = 1, z_2 = 0, z_3 = 0\}. \end{aligned}$$

它们分别表示基础标签没有恰选一个、缺少候选 1 时仍选择候选 3, 以及候选 4 缺少前提。全部赋值有 16 个, 并且

$$|A_1| = 8, \quad |A_2| = 4, \quad |A_3| = 2.$$

交集大小为

$$|A_1 \cap A_2| = 2, \quad |A_1 \cap A_3| = 1, \quad |A_2 \cap A_3| = |A_1 \cap A_2 \cap A_3| = 0.$$

由式 (13.3), 坏赋值共有 $8+4+2-2-1 = 11$ 个, 因此可行赋值有 $16-11 = 5$ 个。它们对应

$$\mathcal{C}_0 = \{\{1\}, \{1, 3\}, \{1, 3, 4\}, \{2\}, \{2, 4\}\}. \quad (13.4)$$

这个计算在第 13.2 节还会由逻辑公式复核。

13.1.4 子集格上的 Möbius 反演

容斥处理的是若干集合的重叠。一个更一般的问题是: 若已知每个 S 上的总量由其全部子集贡献累加而成, 能否还原每个子集自身新增的贡献? 子集按包含关系形成偏序, **Möbius 反演** (Möbius inversion) 给出这一累加变换的逆。

定理 13.2 子集格上的 Möbius 反演 设 $g, h : \mathcal{P}(V) \rightarrow \mathbb{R}$ 满足

$$g(S) = \sum_{T \subseteq S} h(T) \quad \text{对每个 } S \subseteq V. \quad (13.5)$$

则

$$h(S) = \sum_{T \subseteq S} (-1)^{|S|-|T|} g(T). \quad (13.6)$$

反过来, 由式 (13.6) 定义 h 也会恢复式 (13.5)。

更一般的有限偏序集把 $T \subseteq S$ 换成 $T \leq S$ 。其 Möbius 函数由 $\mu(S, S) = 1$ 以及 $\mu(T, S) = -\sum_{T \leq R < S} \mu(T, R)$ 递归确定, 反演系数不再只由 $|S| - |T|$ 决定。本章只使用子集格, 此时递归解恰为 $\mu(T, S) = (-1)^{|S|-|T|}$ 。

证明. 把式 (13.5) 代入反演式右侧并交换有限求和次序, 得到

$$\begin{aligned} \sum_{T \subseteq S} (-1)^{|S|-|T|} g(T) &= \sum_{T \subseteq S} (-1)^{|S|-|T|} \sum_{R \subseteq T} h(R) \\ &= \sum_{R \subseteq S} h(R) \sum_{T: R \subseteq T \subseteq S} (-1)^{|S|-|T|}. \end{aligned}$$

固定 R 后, 中间集合 T 由 $S \setminus R$ 中哪些元素被加入决定。若 $q = |S \setminus R|$, 内层和等于

$$\sum_{j=0}^q \binom{q}{j} (-1)^{q-j} = (1-1)^q.$$

它在 $R = S$ 时为 1, 在 $R \neq S$ 时为 0, 所以全部较小子集的贡献抵消, 只留下 $h(S)$ 。同一抵消关系也证明反向代入恢复 g 。■

在小集合 V_0 上, 假设累计得分具有形式

$$g(S) = 2|S| + 3\mathbb{I}\{\{1, 3\} \subseteq S\} - \mathbb{I}\{\{2, 4\} \subseteq S\}.$$

每个单项贡献 2, 组合 $\{1, 3\}$ 额外贡献 3, 而组合 $\{2, 4\}$ 产生 -1 的交互。四个元素共有 16 个子集。把每个子集的累计值与反演恢复的局部贡献并列, 可以完整核对正向累加与反向消去: 若只观察各子集的累计值, 反演给出

$$h(\{i\}) = g(\{i\}) - g(\emptyset) = 2,$$

以及

$$h(\{1, 3\}) = g(\{1, 3\}) - g(\{1\}) - g(\{3\}) + g(\emptyset) = 3,$$

$$h(\{2, 4\}) = g(\{2, 4\}) - g(\{2\}) - g(\{4\}) + g(\emptyset) = -1.$$

其余大小至少为 2 的局部贡献均为零。反演并没有假设贡献为正; 它只保证累计量与局部交互之间可以互相重构。

表 13.1 四元素子集格上的累计值与局部贡献。除四个单项、交互 $\{1, 3\}$ 和 $\{2, 4\}$ 外，其余局部贡献均为零。

S	$g(S)$	$h(S)$	S	$g(S)$	$h(S)$
$\emptyset$	0	0	$\{1, 2\}$	4	0
$\{1\}$	2	2	$\{1, 3\}$	7	3
$\{2\}$	2	2	$\{1, 4\}$	4	0
$\{3\}$	2	2	$\{2, 3\}$	4	0
$\{4\}$	2	2	$\{2, 4\}$	3	-1
$\{3, 4\}$	4	0	$\{1, 2, 3\}$	9	0
$\{1, 2, 4\}$	5	0	$\{1, 3, 4\}$	9	0
$\{2, 3, 4\}$	5	0	V_0	10	0

例如对 $S = \{1, 2, 3\}$ ，累计值为 $g(S) = 9$ ，三个二元子集的累计值依次为 4, 7, 4，三个单元素累计值之和为 6，且 $g(\emptyset) = 0$ 。反演确实给出

$$h(\{1, 2, 3\}) = 9 - (4 + 7 + 4) + 6 - 0 = 0.$$

把已经恢复的单项贡献 2, 2, 2 与二元贡献 3 重新相加，也得到 $g(\{1, 2, 3\}) = 9$ 。正向累加与反向消去由此可以在同一组数值上相互复核。

容斥原理可以看成同一反演机制作用于指示函数。正负号 $(-1)^{|S|-|T|}$ 不是需要另行记忆的巧合，而是“所有严格更小子集相互抵消”所需的系数。后续无向图模型把对数联合量写成各变量子集的局部交互时，会复用这个结论；图结构承担的额外工作，是证明不构成团的子集交互为零。Möbius 反演本身只是一条有限集合恒等式，不会自动产生图分解，也不保证所得局部项非负。

13.2 逻辑与约束推理

13.2.1 公式把规则变成可检验条件

计数把每个 $\mathbf{z} \in \{0, 1\}^n$ 都视为候选，实际任务却常只允许其中一部分。**布尔公式** (Boolean formula) 用命题变量和逻辑连接词描述允许的赋值。对命题 P, Q ，合取 $P \wedge Q$ 要求两者都真，析取 $P \vee Q$ 要求至少一个为真，否定 $\neg P$ 翻转真假，蕴含 $P \Rightarrow Q$ 则禁止 P 真而 Q 假的情形。蕴含可以改写为

$$P \Rightarrow Q \iff \neg P \vee Q. \quad (13.7)$$

形式上，**赋值** (assignment) 是映射 $\nu : \{z_1, \dots, z_n\} \rightarrow \{\text{false}, \text{true}\}$ ；连接词的真值规则递归地确定 ν 是否满足一个公式。满足公式 Φ 的赋值也称为 Φ 的**模型** (model)，全体模型记为 $\text{Mod}(\Phi)$ 。这个“模型”只指逻辑公式的满足赋值，不等同于后续章节中由参数描述的统计模型。

否定复合命题时, De Morgan 律给出

$$\neg(P \wedge Q) \iff (\neg P \vee \neg Q), \quad \neg(P \vee Q) \iff (\neg P \wedge \neg Q). \quad (13.8)$$

以第一式为例, (P, Q) 依次取 $(0, 0), (0, 1), (1, 0), (1, 1)$ 时, 等式两侧的真值都依次为 1, 1, 1, 0; 第二式同理得到 1, 0, 0, 0。逐行相同证明两边具有相同模型集合, 而不是仅在某个选定赋值上碰巧相等。

把变量 z_i 同时看作命题“候选 i 被选择”, 贯穿例子的规则可写成

$$\Phi(\mathbf{z}) = (z_1 \vee z_2) \wedge (\neg z_1 \vee \neg z_2) \wedge (\neg z_3 \vee z_1) \wedge (\neg z_4 \vee z_2 \vee z_3). \quad (13.9)$$

前两个子句共同表达 z_1, z_2 恰有一个为真; 第三个子句表达 $z_3 \Rightarrow z_1$; 第四个子句表达 $z_4 \Rightarrow (z_2 \vee z_3)$ 。像式 (13.9) 这样由若干析取子句合取而成的公式称为 **合取范式** (conjunctive normal form, CNF)。

赋值 $\mathbf{z}$ 若使 $\Phi(\mathbf{z})$ 为真, 就称它**满足** (satisfy) Φ 。至少存在一个满足赋值时, 公式**可满足** (satisfiable); 不存在时称为不可满足。这里要判断的是

$$\exists \mathbf{z} \in \{0, 1\}^n, \quad \Phi(\mathbf{z}) = \text{true},$$

不是证明 Φ 对每个赋值都真。对每个赋值都真的公式称为永真式; 可满足性与永真性对应不同的量词, 不能混用。

布尔可满足性问题 (Boolean satisfiability problem, SAT) 的输入是一个布尔公式, 输出只回答它是否存在满足赋值。输入限制为 CNF 时称为 CNF-SAT; 进一步要求每个子句至多含三个文字时称为 **3-SAT**。若采用“恰含三个文字”的定义, 可以重复文字补齐较短子句, 不改变可满足性。式 (13.9) 因此既是一个 CNF-SAT 实例, 也是一个 3-SAT 实例。三者共享“是否存在满足赋值”这一判定接口, 但允许的输入语法不同, 不能只凭名称互换实例。

逐项核对式 (13.9) 可得五个满足集合, 正好是式 (13.4) 中的 $\mathcal{C}_0$ 。容斥从违反事件的并集计算数量, 逻辑公式则直接检验一个候选是否合格; 两种表示回答的问题不同, 但结果必须一致。

13.2.2 蕴含、多个模型与冲突

若每个满足 Φ 的赋值也满足命题 Ψ , 记作

$$\Phi \models \Psi,$$

称 Ψ 是 Φ 的**逻辑后承** (logical consequence)。这表示规则已经强制推出 Ψ , 不表示某个求解器碰巧返回了满足 Ψ 的一个答案。例如, 由式 (13.9) 可得

$$\Phi \models (z_3 \Rightarrow \neg z_2),$$

因为 z_3 推出 z_1 , 而 z_1 与 z_2 互斥。还可得

$$\Phi \wedge z_4 \wedge \neg z_2 \models z_3 \wedge z_1.$$

后一结论使用了额外观测 $z_4 = 1, z_2 = 0$, 不能去掉这些条件后仍声称 $\Phi \models z_3$ 。事实上, $\Phi \wedge z_4 \wedge \neg z_2$ 只有 $\{1, 3, 4\}$ 这一个模型; 原公式 Φ 则有五个模型。这组规则因此同时给出了唯一答案、多个答案与下段冲突情形的可复核对照。

规则允许多个模型时, 可满足性只确认“至少有一个答案”。 $\{1\}$ 与 $\{2, 4\}$ 都满足 Φ , 所以规则本身没有在二者之间作出选择。若再加入 z_2 与 z_3 两个单位子句, 公式变为不可满足: z_3 推出 z_1 , 却又要求互斥的 z_2 为真。冲突表示全部硬规则无法同时成立, 不等于程序尚未找到答案。

判断 $\Phi \models \Psi$ 可以转化为一次不可满足性检查:

$$\Phi \models \Psi \iff \Phi \wedge \neg \Psi \text{ 不可满足.} \quad (13.10)$$

若右侧可满足, 其模型就是一个满足 Φ 却违反 Ψ 的反例; 若右侧不可满足, 这样的反例不存在。这个等价关系把全称式的逻辑后承转换为存在反例的搜索。

定义还包含一个容易误读的边界: 若 Φ 本身不可满足, 则 $\text{Mod}(\Phi) = \emptyset$, 因而对任意 Ψ 都有 $\Phi \models \Psi$ 。这称为空真, 并不表示冲突规则提供了关于 Ψ 的有效信息。实际推理通常先检查 Φ 可满足, 再解释它的逻辑后承。

13.2.3 从逻辑子句到零一约束

布尔规则也可以写成关于 $z_i \in \{0, 1\}$ 的代数约束。一个文字若为 z_i , 用数值 z_i 表示; 若为 $\neg z_i$, 用 $1 - z_i$ 表示。子句 $\ell_1 \vee \dots \vee \ell_r$ 恰好等价于

$$\sum_{j=1}^r v(\ell_j) \geq 1, \quad v(z_i) = z_i, \quad v(\neg z_i) = 1 - z_i. \quad (13.11)$$

因为左侧计算为真的文字个数, 至少一个文字为真当且仅当该和不小于 1。

式 (13.9) 因而等价于

$$z_1 + z_2 = 1, \quad z_3 \leq z_1, \quad z_4 \leq z_2 + z_3, \quad \mathbf{z} \in \{0, 1\}^4. \quad (13.12)$$

第一条等式同时包含“至少一个”和“至多一个”。这个代数表示把规则

接到第 3 章的可行域语言, 但变量的整数性仍然关键。

若把 $\mathbf{z} \in \{0, 1\}^4$ 放宽为 $\mathbf{z} \in [0, 1]^4$, 得到一个连续松弛。分数点

$$\mathbf{z} = (1/2, 1/2, 1/2, 1)$$

满足全部松弛约束, 却不是任何逻辑赋值。按阈值 $1/2$ 把各坐标都取为 1, 还会违反 $z_1 + z_2 = 1$ 。松弛点可提供优化界或帮助构造整数解, 但它本身不是规则系统的合法答案; 取整后必须重新核对原约束。

13.2.4 硬约束与软代价

硬约束 (hard constraint) 直接定义可行集合, 违反任意一条就不是候选答案。有些规则表达偏好而非绝对禁止, 此时可以为违反规则设置非负代价。令 $r_j(\mathbf{z}) \in \{0, 1\}$ 表示第 j 条规则是否被违反, 权重 $\lambda_j \geq 0$, 则可以最小化

$$c(\mathbf{z}) + \sum_{j=1}^m \lambda_j r_j(\mathbf{z}), \quad \mathbf{z} \in \{0, 1\}^n. \quad (13.13)$$

c 是任务本身的代价, 第二项为规则冲突计分。权重有限时, 足够大的任务收益可能抵消违反规则的代价, 所以软规则不再具有逻辑蕴含意义。

把 λ_j 取得很大也不能未经证明就等同于硬约束。若 c 的变化范围已知, 例如 $|c(\mathbf{z}) - c(\mathbf{z}')| \leq B$ 对任意赋值成立, 并且存在一个不违反任何软规则的赋值 $\mathbf{z}_0$, 那么令每个 $\lambda_j > B$ 可以排除所有带违反项的全局最优解: 任一违规赋值的目标值严格大于 $c(\mathbf{z}_0)$ 。若不存在零违反赋值、无法给出可用的 B , 或希望一族不同规模的实例共用罚权而 c 的振幅没有统一上界, 或者只把部分权重取得较大, 这个论证便不成立。硬约束、罚函数和带松弛变量的约束各自改变了可行性或比较准则, 使用时应明确允许返回什么答案。

13.3 组合优化与次模性

13.3.1 可行性、最优性与求解代价

规则确定集合族 $\mathcal{C} \subseteq \mathcal{P}(V)$ 后, 仍需用目标函数比较不同可行集合。一个有限组合优化问题可写成

$$\max_{S \in \mathcal{C}} F(S) \quad \text{或} \quad \min_{S \in \mathcal{C}} C(S). \quad (13.14)$$

由于 $\mathcal{C}$ 有限且非空, 实值目标一定达到最优值。这只回答存在性; 验证 $S \in \mathcal{C}$ 、计算 $F(S)$ 以及在不枚举全部候选的情况下找到最优解, 仍是不同任务。存在性的证明只需把 $\mathcal{C} = \{S_1, \dots, S_N\}$ 列成有限序列: 有限个实数 $F(S_1), \dots, F(S_N)$ 可逐项比较并取得最大值, 达到该值的某个 S_i 就是最优

解。最小化结论可对 $-C$ 应用同一论证。若 $\mathcal{C} = \emptyset$ ，则没有可行解；若目标允许取无穷值，也需另外说明所用的大小关系。因此“有限”“非空”和“实值”都是这个存在性结论的条件。

继续使用四个候选。设需求集合为 $R = \{a, b, c, d, e\}$ ，各候选覆盖

$$Q_1 = \{a, b\}, \quad Q_2 = \{b, c, d\}, \quad Q_3 = \{c, e\}, \quad Q_4 = \{d, e\}.$$

定义覆盖收益

$$F(S) = \left| \bigcup_{i \in S} Q_i \right|. \quad (13.15)$$

在 $\mathcal{C}_0$ 的五个可行集合上，收益依次为 2, 4, 5, 3, 4，所以 $\{1, 3, 4\}$ 达到最优值 5。这里最优解可以直接列举得到，因为例子只有五个候选集合；若 n 增大， 2^n 个赋值的枚举时间很快就会成为主要障碍。

只检查局部交换也不能替代全局比较。设可行集合是 $V = \{1, 2, 3, 4\}$ 的所有二元子集，并规定 $F(\{1, 2\}) = 1$ 、 $F(\{3, 4\}) = 3$ ，其余二元子集的值均为 0。从 $\{1, 2\}$ 出发，替换其中任一元素都会使目标降为 0，所以它是一交换局部最优解；全局最优解却是 $\{3, 4\}$ 。局部最优能否推出全局最优，必须来自目标与可行域的额外结构。

近似解的误差也要先约定口径。对非负最大化目标，若算法输出 $\hat{S}$ 满足 $F(\hat{S}) \geq \alpha F(S^*)$ ，称其具有 α 乘法近似，其中 $0 \leq \alpha \leq 1$ ；若满足 $F(S^*) - F(\hat{S}) \leq \varepsilon$ ，则是加法误差不超过 ε 。当最优值为 0 或目标可取负值时，乘法比例可能失去区分力，加法误差或经过说明的平移、归一化口径更合适。

若每个候选还有成本 $c_i \geq 0$ ，可以最大化 $F(S) - \sum_{i \in S} c_i$ ，也可以在预算 $\sum_{i \in S} c_i \leq B$ 下最大化 $F(S)$ 。这两个问题通常不等价：固定罚权隐含一种收益与成本交换率，预算约束则禁止所有超额集合。要断言对给定预算存在某个乘子并使两类问题的最优解对应，需要第 3 章所述的额外对偶条件。一般离散问题不保证这样的乘子存在，不能只凭形式相似互换两类问题。

13.3.2 边际收益递减

一般集合函数可以任意指定每个子集的值，几乎没有可利用的结构。**次模函数** (submodular function) 要求已选择的集合越大，再加入同一元素所得的边际收益越小。正式地， $F : \mathcal{P}(V) \rightarrow \mathbb{R}$ 若对所有 $A \subseteq B \subseteq V$ 和 $e \in V \setminus B$ 满足

$$F(A \cup \{e\}) - F(A) \geq F(B \cup \{e\}) - F(B), \quad (13.16)$$

就称 F 为次模函数。记

$$\Delta(e | A) = F(A \cup \{e\}) - F(A)$$

后, 式 (13.16) 表示 $\Delta(e | A) \geq \Delta(e | B)$ 。

次模性不等于**单调性** (monotonicity)。单调函数要求 $A \subseteq B$ 时 $F(A) \leq F(B)$, 也就是所有边际收益非负; 次模函数允许边际收益为负, 只要求它随上下文扩大而不增加。模函数 $F(S) = c + \sum_{i \in S} w_i$ 的边际收益与上下文无关, 因此同时是次模和超模函数, 不论某些 w_i 是否为负。

互补收益给出次模性失效的最小反例。令 $G(S) = |\{1, 3\} \subseteq S|$ 。把元素 3 加入空集的边际收益为 0, 把它加入 $\{1\}$ 的边际收益却为 1。由于 $0 < 1$, 边际收益随上下文增大而上升, G 不是次模函数。这个例子区分了“两个元素共同出现才有收益”的互补关系与覆盖函数中的替代关系。

次模性还有一个对称的交并形式。

定理 13.3 次模性的两个等价定义 集合函数 $F : \mathcal{P}(V) \rightarrow \mathbb{R}$ 满足边际收益递减式 (13.16), 当且仅当对任意 $A, B \subseteq V$ 有

$$F(A) + F(B) \geq F(A \cup B) + F(A \cap B). \quad (13.17)$$

证明. 先假设边际收益递减。把 $A \setminus B$ 中的元素依次记为 $e_1, \dots, e_r$ 。从 $A \cap B$ 加入这些元素得到 A , 从 B 加入同一序列得到 $A \cup B$ 。在第 j 步, 前一条路径的当前集合包含于后一条路径的当前集合, 因此

$$F(A) - F(A \cap B) \geq F(A \cup B) - F(B).$$

移项即得式 (13.17)。

反过来, 取 $A \subseteq B$ 和 $e \notin B$, 将交并不等式用于 $A \cup \{e\}$ 与 B 。二者的交为 A , 并为 $B \cup \{e\}$, 故

$$F(A \cup \{e\}) + F(B) \geq F(B \cup \{e\}) + F(A).$$

移项便得到式 (13.16)。 ■

13.3.3 覆盖函数为何次模

式 (13.15) 是次模性的典型来源。更一般地, 为每个需求 $r \in R$ 给定权重 $w_r \geq 0$, 定义

$$F(S) = \sum_{r \in \bigcup_{i \in S} Q_i} w_r. \quad (13.18)$$

定理 13.4 非负加权覆盖函数单调且次模 若所有 $w_r \geq 0$, 则式 (13.18) 定义的 F 是单调次模函数, 并满足 $F(\emptyset) = 0$ 。

证明. 空集合不覆盖任何需求, 所以 $F(\emptyset) = 0$ 。若 $A \subseteq B$, 则 A 覆盖的需求也被 B 覆盖; 权重非负保证 $F(A) \leq F(B)$ 。对 $A \subseteq B$ 和 $e \notin B$, 加入 e 的边际收益是

$$\Delta(e | A) = \sum_{r \in Q_e \setminus \bigcup_{i \in A} Q_i} w_r.$$

由于 $\bigcup_{i \in A} Q_i \subseteq \bigcup_{i \in B} Q_i$, 在 B 的基础上尚未覆盖的 Q_e 元素不会比在 A 的基础上更多。逐项使用 $w_r \geq 0$, 得到 $\Delta(e | A) \geq \Delta(e | B)$ 。 ■

在贯穿例子中, 候选 3 单独加入空集时新增 $\{c, e\}$, 边际收益为 2; 若已经选择 $\{2\}$, 需求 c 已经覆盖, 加入 3 只新增 e , 边际收益降为 1。这个计算展示了式 (13.16) 的一种情形, 但一般结论来自上面的集合包含证明, 而不是来自一个数值例子。

非负权重是单调性证明的实质条件。若某个被覆盖对象具有负权重, 增加候选可能降低目标; 函数是否仍次模要按具体形式检查。两个次模函数之和仍次模, 非负倍数也保持次模性, 但次模函数之差一般不次模。给覆盖收益减去模块化成本仍是次模函数, 却可能失去单调性。

13.3.4 基数约束下的贪心保证

次模性约束边际收益之间的关系, 但只有与特定可行域和算法结合, 才能得到求解保证¹。考虑归一化单调次模最大化

$$\max_{S \subseteq V, |S| \leq k} F(S), \quad F(\emptyset) = 0.$$

贪心算法从 $S^{(0)} = \emptyset$ 开始, 在第 t 步选择边际收益最大的元素

$$e^{(t)} \in \arg \max_{e \in V \setminus S^{(t)}} \Delta(e | S^{(t)}), \quad S^{(t+1)} = S^{(t)} \cup \{e^{(t)}\}.$$

平局可按固定顺序处理, 使算法输出确定。

定理 13.5 单调次模最大化的贪心界 设 $1 \leq k \leq |V|$, F 归一化、单调且次模, S^* 是在 $|S| \leq k$ 下的最优解。上述贪心算法运行 k 步得到 $S^{(k)}$, 则

$$F(S^{(k)}) \geq \left(1 - \left(1 - \frac{1}{k}\right)^k\right) F(S^*) \geq (1 - e^{-1}) F(S^*). \quad (13.19)$$

¹ G. L. Nemhauser, L. A. Wolsey, M. L. Fisher, *An Analysis of Approximations for Maximizing Submodular Set Functions—I* In *Mathematical Programming*, 1978, vol. 14, pp. 265–294

证明. 固定第 t 步. 由单调性、次模性以及逐个加入 $S^* \setminus S^{(t)}$ 中的元素,

$$\begin{aligned} F(S^*) - F(S^{(t)}) &\leq F(S^{(t)} \cup S^*) - F(S^{(t)}) \\ &\leq \sum_{e \in S^* \setminus S^{(t)}} \Delta(e | S^{(t)}). \end{aligned}$$

右侧至多有 k 项, 所以其中至少一项不小于 $[F(S^*) - F(S^{(t)})]/k$. 若右侧没有元素, 则单调性已经给出 $F(S^{(t)}) \geq F(S^*)$, 所需递推平凡成立; 否则贪心选择的边际收益不小于上述某一项, 故

$$F(S^{(t+1)}) - F(S^{(t)}) \geq \frac{F(S^*) - F(S^{(t)})}{k}.$$

令剩余差距 $r^{(t)} = F(S^*) - F(S^{(t)})$, 便有 $r^{(t+1)} \leq (1 - 1/k)r^{(t)}$. 由 $F(S^{(0)}) = 0$ 递推得到

$$r^{(k)} \leq \left(1 - \frac{1}{k}\right)^k F(S^*),$$

移项给出第一个不等式. 再用 $(1 - 1/k)^k \leq e^{-1}$ 得到第二个不等式. ■

定理 13.5 不能直接套到式 (13.4). 逻辑规则形成的 $\mathcal{C}_0$ 不是普通基数约束, 甚至不是向下封闭的: $\{1, 3\}$ 可行, 其子集 $\{3\}$ 却不可行. 逐个加入当前边际收益最大的元素可能在中途违反规则, 或走入无法扩展到最优解的分支. 其他约束下可以有不同的贪心、连续松弛或近似结果, 但保证必须重新证明, 不能只凭目标具有次模性.

13.3.5 连续松弛、界与离散答案

把整数可行集 $\mathcal{C}$ 嵌入 $\{0, 1\}^n$ 后, 可以用一个较大的连续集合 $P \subseteq [0, 1]^n$ 包住它. 对最大化问题, 若连续目标在整数点上与原目标一致, 松弛最优值通常给出原最优值的上界; 任何取整后可行解则给出下界. 对最小化问题方向相反. 这与第 3.8 节的上下界口径一致.

例如考虑

$$\max z_1 + z_2 \quad \text{s.t.} \quad 2z_1 + 2z_2 \leq 3, \quad z_1, z_2 \in \{0, 1\}.$$

整数最优值为 1. 放宽为 $0 \leq z_1, z_2 \leq 1$ 后, $(z_1, z_2) = (1, 1/2)$ 可取得松弛最优值 $3/2$, 确实是整数最优值的上界. 若把正坐标都取为 1, 则得到 $(1, 1)$ 并违反容量约束; 若把 $1/2$ 向下取整, 则恢复一个值为 1 的可行解. 这个算例同时展示了松弛界、取整可行性与取整后目标值是三项不同检查.

即使松弛已经精确描述整数点的凸包, 求得的分数最优点也可能位于一个最优面内部. 线性目标保证同一最优面上至少有整数极点, 不表示任意返回的分数点都能逐坐标取整. 若松弛比凸包更大, 还可能出现**整数间隙** (integrality gap): 松弛最优值严格优于所有整数可行解. 因而应分别

记录松弛值、取整后的可行值及二者差距。

集合函数的连续扩展也有多种选择。无论采用何种扩展，连续变量上的凸性或凹性都不能仅由“原函数次模”一句话替代；扩展方式决定可用的优化工具。第 14 章会讨论一个可精确求解的特殊情形：二值成对能量满足相应次模不等式时，可以表示为非负容量的割。这里建立的一般集合函数定义本身并不保证任意次模最大化或最小化都能用图割解决。

13.4 可计算性与复杂度

13.4.1 先规定输入怎样交给程序

复杂度不是对象本身附带的标签，而是相对于输入编码、计算模型和所求输出定义的。对有限变量问题，可以把 n 、CNF 公式、整数或有理数权重以及阈值写成有限比特串。输入长度记为 L ，它包括变量索引、子句、数值的二进制位数和分隔信息。若一个权重需要 b 位表示，读取和比较它就不能无条件算作与 b 无关的一步。

同一优化任务常对应三个不同计算问题。

- **搜索问题**要求返回一个满足 Φ 的 $\mathbf{z}$ ；
- **优化问题**要求返回目标最优的可行 $\mathbf{z}$ 或最优值；
- **判定问题**只问是否存在满足 Φ 且 $F(S(\mathbf{z})) \geq K$ 的赋值。

复杂性类别通常先为判定问题定义。若能多次调用判定算法并固定变量，常可恢复一个解；但调用次数、数值精度和自归约结构都要计入，不能把“知道答案存在”直接当作已经构造答案。

13.4.2 可枚举、可判定与可计算

一个对象集合若存在程序依次输出其中全部对象，称为**可枚举的**（com-putably enumerable）。这里要求程序只输出该集合中的对象，并最终输出其中每个对象；程序可以重复输出，也不必告诉我们某个尚未出现的对象以后是否会出现。一个判定问题若存在程序对每个合法输入都在有限步内停机，并正确回答“是”或“否”，称为**可判定的**（decidable）。若程序只保证在“是”实例上最终停机并接受，而在“否”实例上可能永不停止，则称该问题**半可判定的**（semidecidable）。类似地，字符串上的函数 f 若存在一个程序，对定义域内每个输入 x 都停机并输出 $f(x)$ ，就称 f 为**可计算函数**（computable function）。判定问题可看作计算取值为 0 或 1 的特征函数，因此可判定性比只确认正例的半可判定性要求更强。

可枚举不等于可判定。若某集合及其补集都可枚举，可以交错运行两个枚举或半判定程序：输入最终会被其中一方确认，于是得到判定程序。若只有正例可枚举，等待尚未出现的对象无法证明它永远不会出现。

在明确的有限编码下，CNF 可满足性是可判定的。按字典序枚举全部 2^n 个赋值，每个赋值逐子句检查；找到满足赋值就回答“是”，全部检查完仍未找到则回答“否”。若公式有 m 个子句、总文字出现次数为 q ，直接实现需要 $O(2^n q)$ 量级的时间和存放当前赋值及公式所需的内存。这个算法很慢，但一定停机，所以它证明了可判定性。

“每个实例的候选集有限”还不足以独立构成上述证明。程序必须能从输入有效得到候选编码，能判定一个候选是否满足约束，并能知道枚举何时完成。若把一个不可计算实数或一个可能不停机的黑盒藏进“目标求值”，有限个候选也未必能被统一程序比较。可计算性要求的是对整族输入存在同一个有限描述的程序。

13.4.3 存在不可判定的问题

有限变量问题在有效表示下可以穷举，但一般程序的行为并非总能判定。令

$$\text{HALT} = \{(P, x) : \text{程序 } P \text{ 在输入 } x \text{ 上最终停机}\}.$$

它是半可判定的：模拟 $P(x)$ ，若模拟停止就接受；若 $P(x)$ 永不停止，模拟也不会给出否定答案。下面的对角论证说明不存在总能判断停机与否的程序。

停机问题的不可判定性是可计算性理论的基本结论²。

定理 13.6 停机问题不可判定 HALT 不可判定。

证明. 反设存在判定程序 $H(P, x)$ ，它总会停机，并在 $P(x)$ 停机时返回 1，否则返回 0。据此构造程序 D ：输入一个程序编码 P ，先计算 $H(P, P)$ ；若结果为 1，就进入无限循环；若结果为 0，就立即停机。

现在把 D 自己的编码交给 D 。若 $H(D, D) = 1$ ，按照 D 的定义， $D(D)$ 进入无限循环，与 H 判断它会停机矛盾。若 $H(D, D) = 0$ ， $D(D)$ 立即停机，又与 H 判断它不停机矛盾。两种返回值都导致矛盾，所以这样的判定程序 H 不存在。 ■

定理 13.6 区分了“某次模拟尚未结束”和“已经证明不会结束”。前者是有限时刻的观察，后者要求排除所有未来时刻。不可判定也不等于每个具体程序都无法分析；许多程序可由终止度量、循环不变量或有限状态搜索证明停机。结论是不存在一个对任意程序和输入都正确的统一判定器。

² A. M. Turing, *On Computable Numbers, with an Application to the Entscheidungsproblem* In *Proceedings of the London Mathematical Society*, 1937, vol. 42, no. 1, pp. 230–265

13.4.4 多项式时间、证书与复杂性类别

可判定问题仍可能需要随输入长度急剧增长的资源。若一个确定性算法的最坏运行时间由 L 的某个固定次数多项式控制，该判定问题属于复杂性类别 P 。类别 NP 包含满足如下条件的判定问题 $\mathcal{L}$ ：存在多项式 p 和确定性多项式时间验证程序 Ver ，使每个输入 x 都满足

$$x \in \mathcal{L} \iff \exists y, |y| \leq p(|x|), Ver(x, y) = 1.$$

其中 $|x|$ 是输入的比特长度， y 称为**证书** (certificate)。双向条件不仅要求每个“是”实例存在可接受的多项式长度证书，还要求“否”实例的所有这类证书都被拒绝。名称中的“非确定性”描述这种猜测证书后验证的计算模型，不表示算法可以容忍随机错误。确定性多项式算法的运行轨迹本身可作证书，所以 $P \subseteq NP$ 。目前并不知道这个包含是否严格；把 $P \neq NP$ 当作已经证明的事实，会超出这里可用的结论。

CNF 可满足性属于 NP 。证书就是 n 位赋值 z ，验证程序逐个检查子句，时间关于公式长度为线性量级。穷举证明它可判定，短证书证明它属于 NP ；二者都没有给出多项式时间的求解算法。

若问题 A 的每个实例 x 都能在多项式时间内变换为问题 B 的实例 $f(x)$ ，并满足

$$x \in A \iff f(x) \in B,$$

就称 A 可**多项式时间多对一归约** (polynomial-time many-one reduction) 到 B ，记作 $A \leq_p B$ 。归约方向表示：若能高效解决 B ，就能先计算 $f(x)$ 再高效解决 A 。因此从已知困难问题归约到新问题，才能证明新问题至少同样困难；把方向写反不会得到这个结论。

一个问题若所有 NP 问题都可多项式时间归约到它，就称为 **NP 困难** (NP-hard)；若它还属于 NP ，就称为 **NP 完全** (NP-complete)。Cook-Levin 定理给出 SAT 是 NP 完全问题³。通过引入辅助变量，可以把一般公式在多项式时间内变成等可满足的 CNF 公式；再把长子句拆成由辅助变量连接的三文字子句，可以归约到 3-SAT。这里的“等可满足”只保证原公式有解当且仅当新公式有解，不要求辅助变量加入后两个公式拥有相同的模型集合。由这些接口可知 CNF-SAT 与 3-SAT 也都是 NP 完全问题。这里把结论作为复杂度理论的基准，不展开对任意多项式时间验证计算的编码证明；下面只证明与本章约束表示直接相关的归约。

³S. A. Cook, *The Complexity of Theorem-Proving Procedures* In Proceedings of the Third Annual ACM Symposium on Theory of Computing, 1971, pp. 151–158

定理 13.7 CNF 可满足性归约到零一线性可行性 给定任意 CNF 公式，可以在关于公式长度的多项式时间内构造一组零一线性不等式，使该公式可满足当且仅当这些不等式存在零一可行解。因此零一线

性可行性是 NP 困难的；当所有整数系数按二进制编码时，它也属于 NP，因而是 NP 完全的。

证明. 为每个命题变量建立 $z_i \in \{0, 1\}$ 。对每个子句 $C = \ell_1 \vee \cdots \vee \ell_r$ ，加入式 (13.11)：

$$\sum_{j=1}^r v(\ell_j) \geq 1.$$

每个文字只产生一个系数为 1 的变量项或 $1 - z_i$ ，所以构造时间和输出长度都关于原公式长度为线性量级。

若原公式有满足赋值，把真假分别编码为 1, 0。每个子句至少一个文字为真，对应不等式左侧至少为 1，所以得到零一可行解。反过来，任一零一可行解定义一个布尔赋值；每条不等式左侧至少为 1，说明相应子句至少一个文字为真，故全部子句同时满足。两边可行性等价，归约成立。

由 CNF 可满足性的 NP 困难性，零一线性可行性 NP 困难。对其 NP 成员关系，证书是一组零一变量值；验证者按二进制整数运算检查所有不等式，所需时间关于输入和证书长度为多项式。 ■

定理 13.7 说明，换成代数记号不会自动消除逻辑搜索的困难。它也没有声称每个零一线性实例都难：式 (13.12) 只有四个变量，可以立即求解；某些约束矩阵或关系结构还允许专门的多项式算法。NP 完全描述的是一族问题在最坏情况下的归约地位，不是每个实例的运行时间预测。

13.4.5 复杂度结论的边界

输入规模必须与算法成本使用同一口径。枚举 2^n 个赋值是关于变量数 n 的指数时间；若输入本身已经显式列出全部 2^n 个候选，那么扫描列表反而关于输入长度是线性的。把隐式表示与显式列表混在一起，会让同一算法同时被误称为指数和线性。

数值大小也不能替代编码长度。若整数 N 用二进制给出，输入它只需 $\lceil \log_2 N \rceil + 1$ 位；执行 N 轮的循环关于数值 N 是线性的，却关于输入位数是指数级的。运行时间关于数值大小是多项式、关于二进制输入长度却未必是多项式的算法，称为**伪多项式时间算法** (pseudo-polynomial-time algorithm)。只有同时说明数值编码与所计基本运算，才能判断一个界是否真正关于输入长度为多项式。

最坏情况复杂度也不同于一次实验运行时间。某个求解器在当前数据上很快，可能来自实例结构、预处理或启发式分支顺序；这不能证明问题属于 P。反过来，NP 完全性不排除小实例、特殊结构、参数受限情形或近

似目标能够高效求解。应说明保证针对精确解、近似值还是可行解，并列明依赖的参数与表示。

统计样本量与计算时间同样不能互相替代。一个候选族可能只需较少样本就能控制泛化误差，经验风险最小化却仍难以计算；也可能存在高效优化算法，但样本不足以区分多个预测规则。可计算学习还要求训练程序和输出的预测程序都停机，高效学习进一步要求相应资源由规定参数的多项式控制。组合计数可以进入统计界，也可以进入枚举成本，但两处的规模对象和结论必须分别核对。

13.5 本章小结

有限离散问题至少包含四层约束。集合族与计数说明候选空间有多大；容斥校正重叠事件，Möbius 反演则从所有子集的累计量恢复局部贡献。二者共享交替抵消机制，但反演本身只提供代数重构，不会自动给出概率因子分解或非负局部项。

逻辑公式规定哪些赋值允许。可满足表示至少存在一个模型，逻辑后承要求所有模型都满足结论，不可满足则表示硬规则冲突。把子句改写为零一不等式可以接入优化工具，连续松弛和软代价却改变了答案对象；分数解、取整结果和硬约束模型必须分开核对。

目标函数在可行集合之间作选择。次模性刻画边际收益递减，单调性另行要求增加元素不降低目标。归一化单调次模函数在基数约束下具有贪心近似界，但一般逻辑约束、非单调目标或其他松弛都需要新的算法条件。候选有限保证最优值存在，不保证无需枚举就能找到最优解。

计算层面还要依次区分可判定、可计算和多项式时间。穷举证明有效表示下的有限 CNF 问题可判定，停机问题说明一般程序性质可能不可判定，归约则比较可判定问题的最坏情况难度。经验运行时间不能替代复杂度证明，NP 完全性也不排除特殊结构上的高效算法。第 14 章将把本章变量之间的关系表示为图，研究分解、路径与局部结构怎样改变计算组织。

第 14 章

图论

第 13 章用 $z_1, \dots, z_4$ 四个二值变量说明有限变量、约束与目标。本章不增加变量，而是直接从式 (13.9) 的约束作用域构造 **原始关系图** (primal graph)：每个二值变量对应一个顶点，同一子句中的任意两个变量相连。前两个子句给出边 $\{1, 2\}$ ，第三个子句给出边 $\{1, 3\}$ ，三变量子句 $\neg z_4 \vee z_2 \vee z_3$ 则使 $2, 3, 4$ 三个顶点两两相连；这样的顶点集合后文称为团。图只记录哪些变量需要在同一个局部约束中共同处理；三变量子句仍是一个三元约束，不能把这三条边误解为三个与原子句等价的二元约束。

贯穿例固定第 13 章的四个二值变量：

$$z_i \in \{0, 1\}, \quad i \in V = \{1, 2, 3, 4\}.$$

讨论不依赖二值性的图算法时，用有限集合 z_i 表示变量 z_i 的一般取值域；贯穿例对应 $z_i = \{0, 1\}$ 。图 14.1 中的边表示哪些变量共同出现在某个约束中。边集合为

$$E = \{\{1, 2\}, \{1, 3\}, \{2, 3\}, \{2, 4\}, \{3, 4\}\}. \quad (14.1)$$

这张图很小，却包含本章需要分开的几种作用。两个三角形 $\{1, 2, 3\}$ 与 $\{2, 3, 4\}$ 共享接口 $\{2, 3\}$ ，所以固定接口后，只含 z_1 与只含 z_4 的局部计算可以分开。若过早消去顶点 2，原本不相邻的顶点 1, 4 会在中间结果中直接联系。同一连接结构可以承载硬约束、概率、得分、距离或容量，但这些数值语义并不由图本身决定。




图 14.1 由第 13 章约束作用域导出的变量关系图。每条边表示两个变量共同出现在至少一个约束中；共享边 $\{2, 3\}$ 是左右两个三角形的接口。边权、方向与关系的数值含义需要另行给出。

本章先建立图的对象与表示，再研究遍历、分离和树分解怎样揭示局部结构。分解只说明计算应如何组织，真正计算什么还由代数运算决定，因此第 14.3 节用半环统一边缘化、最优赋值与最短路径。第 14.4 节比较几类精确图算法及其条件，并完整推导二值次模能量的最小割表示；一般离散目标不具备这些结构时，仍可用枚举或分支定界精确搜索，但最坏情形通常代价很高；也可借助松弛、取整或局部搜索获得近似解与上下界证书。最后一节把顶点上的数值看作图信号，用图拉普拉斯连接平滑、分割与扩散，并检验顶点重编号下哪些表示保持不变。

14.1 图的对象与表示

14.1.1 顶点与边只规定关系的骨架

无向图 (undirected graph) 是二元组

$$\mathcal{G} = (V, E),$$

其中 V 是顶点集合， E 是由不同顶点组成的无序对集合。若 $\{i, j\} \in E$ ，就称 i, j 相邻，并把二者分别称为对方的邻居。顶点 i 的 **邻域** (neighborhood) 与 **度** (degree) 分别为

$$N(i) = \{j \in V : \{i, j\} \in E\}, \quad d_i = |N(i)|.$$

式 (14.1) 定义的图中， $N(2) = \{1, 3, 4\}$ ，而 $N(1) = \{2, 3\}$ 。这里采用不含自环、平行边的有限简单图；若任务允许自环或同一对顶点间有多条边，必须把边集合改为相应的多重结构。

无向边表达对称关系。若关系具有先后或作用方向，就使用 **有向图** (directed graph) $\mathcal{G} = (V, A)$ ，其中 $A \subseteq V \times V$ 由有序对组成。 $(i, j) \in A$ 表示从 i 指向 j ，不自动推出 $(j, i) \in A$ 。指向顶点 j 的弧称为 j 的入边，入边条数称为 **入度** (in-degree)；从 j 指出的弧称为出边，其条数称为 **出度** (out-degree)。因果生成次序、状态转移和计算依赖通常需要有向边；距离邻接或对称相似性通常使用无向边。

边还可以带有**权重** (weight)。无向加权图要求 $w_{i,j} = w_{j,i}$ ，有向加权图则允许二者不同。权重可以表示长度、容量、相似度或局部代价；这些量对“权重大”的解释不同，所以每个算法都须重新声明权重语义。本章不统一排除零权边：结构边集 E 记录哪些关系存在，而对无向非负权图，

$$E_+ = \{\{i, j\} \in E : w_{i,j} > 0\}$$

称为**正权支撑** (positive-weight support)。当权重作为线性算子的系数时，零权结构边不产生贡献，相关的谱与扩散结论因而取决于支撑图 $\mathcal{G}_+ =$

(V, E_+) 。

成对边有时仍不足以表达局部关系。若一个约束同时作用于 $\{1, 3, 4\}$, 把它拆成三条边可能改变允许的赋值。此时使用**超图** (hypergraph), 其超边可以包含两个以上顶点。也可使用**二部图** (bipartite graph) 把顶点分成两组, 只允许跨组边。变量与局部因子形成的因子图就是二部图, 它保留了高阶关系同时涉及哪些变量。

14.1.2 路径与环描述局部边怎样组成整体连接

图中的**游走** (walk) 是顶点序列 $v_0, v_1, \dots, v_k$, 相邻两项之间有边; 顶点与边可以重复。若 $v_0, \dots, v_k$ 两两不同, 就得到**路径** (path)。长度是经过的边数; 在带长度的图上, 路径长度改为边长之和。无向图中的**环** (cycle) 是长度 $k \geq 3$ 的闭游走 $v_0, v_1, \dots, v_k$, 其中 $v_0 = v_k$, 而 $v_0, \dots, v_{k-1}$ 两两不同。因此环只在首尾重复同一顶点, 不与路径要求全部顶点互异的定义混用。

若任意两个顶点间都有路径, 无向图称为**连通** (connected)。一般无向图可以唯一分成若干极大的连通子图, 称为连通分量。图 14.1 连通, 因为每个顶点都能经顶点 3 到达其他顶点; 1, 2, 3, 1 与 2, 3, 4, 2 分别构成一个环。删除边 $\{1, 2\}$ 后图仍连通, 但第一个环消失。

连通且无环的无向图称为**树** (tree)。树中任意两点之间恰有一条简单路径: 两条不同路径从分开到重新会合的部分会构成环。含 n 个顶点的树恰有 $n - 1$ 条边, 若干棵互不相连的树组成森林。下面把路径唯一性和边数结论合在一起证明, 因为二者分别解释树为何适合递推, 以及递推中为何不会遗漏额外连接。

定理 14.1 树的等价刻画 对含 $n \geq 1$ 个顶点的有限无向简单图, 以下三条等价:

1. 图连通且无环;
2. 任意两点之间恰有一条简单路径;
3. 图连通, 并且恰有 $n - 1$ 条边。

证明. 若图连通且无环, 任意两点间至少有一条简单路径; 若有两条不同的简单路径, 从二者首次分开处走到再次会合处便得到一个环, 产生矛盾, 故路径唯一。反过来, 路径唯一已经包含连通性; 若图有环, 环上相邻顶点之间既有该边, 又有沿环另一侧的路径, 与唯一性矛盾。

再证明边数。单顶点树有 0 条边。含至少两个顶点的有限树必有叶顶点: 取一条最长简单路径, 端点若还有路径外邻居, 就能延长该路径; 端点若连接路径中的非相邻顶点, 又会形成环。删除叶顶点及其唯一关联边

后仍是树，归纳得到边数 $(n-1)-1+1=n-1$ 。树中任意边又位于其两端的唯一简单路径上，删除该边必使两端断开。

最后，设图连通且有 $n-1$ 条边。从任一顶点开始，每次加入一条连接“已加入顶点”与“尚未加入顶点”的边；连通性保证只要还有顶点未加入，这样的边就存在。加入一个新顶点不会形成环，重复 $n-1$ 次便得到一棵覆盖全部顶点的树。该树已经使用原图的全部 $n-1$ 条边，所以原图与这棵树相同，因而无环。 ■

有向图中的路径必须顺着弧方向前进。**有向环** (directed cycle) 是除首尾外顶点互异、每一步都沿弧方向的闭游走。在不含自环的有向图中，有向环长度至少为 2：若 $i \rightarrow j$ 与 $j \rightarrow i$ 同时存在，二者已经构成有向环；这与无向简单图的环至少包含三个顶点不同。不含有向环的图称为 **有向无环图** (directed acyclic graph, DAG)。DAG 中的边可以规定偏序依赖，但图中没有边的两个顶点不一定可以互换执行，它们还可能通过更长路径间接依赖。后文的拓扑排序会把这种偏序扩展为一个线性次序。

有向图还需区分两种连通性。若任意有序顶点对 i, j 之间都有从 i 到 j 的有向路径，图称为**强连通** (strongly connected)；若忽略弧方向后所得无向图连通，则称为**弱连通** (weakly connected)。强连通蕴含弱连通，反向不成立。例如单向链 $1 \rightarrow 2 \rightarrow 3$ 弱连通，却不存在从 3 返回 1 的有向路径。

14.1.3 邻接矩阵把关系写成线性映射

给顶点固定次序 $1, \dots, n$ ，无向图的**邻接矩阵** (adjacency matrix) $\mathbf{A} \in \mathbb{R}^{n \times n}$ 定义为

$$a_{i,j} = \begin{cases} w_{i,j}, & \{i, j\} \in E, \\ 0, & \text{其他情形.} \end{cases}$$

无权图取 $w_{i,j} = 1$ 。无向图使 $\mathbf{A}$ 对称；有向图则令 $a_{i,j}$ 记录弧 $i \rightarrow j$ 的权重，一般不对称。简单无向图没有自环，所以主对角线为零。若允许结构边的权重为 0，数值矩阵中的零条目不能区分零权边与无边，此时必须把 $\mathbf{A}$ 与边集 E 或一个邻接掩码一同保存；只有在所有结构边权非零时， $\mathbf{A}$ 才单独确定边集。图 14.1 的邻接矩阵是

$$\mathbf{A} = \begin{bmatrix} 0 & 1 & 1 & 0 \\ 1 & 0 & 1 & 1 \\ 1 & 1 & 0 & 1 \\ 0 & 1 & 1 & 0 \end{bmatrix}. \quad (14.2)$$

邻接矩阵不只是存储表。对顶点数值 $\mathbf{f} = (f_1, \dots, f_n)^\top$,

$$(\mathbf{A}\mathbf{f})_i = \sum_{j \in N(i)} w_{i,j} f_j$$

汇总顶点 i 的邻居值, 因此是第 5 章意义下的线性映射。矩阵幂还记录游走: 对无权图, $(\mathbf{A}^k)_{i,j}$ 等于从 i 到 j 长度为 k 的游走数。证明只需对 k 归纳; 矩阵乘法在中间顶点 ℓ 上求和, 恰好把长度 k 的游走与最后一条边拼接。游走允许重复顶点, 所以该数一般不等于简单路径数。对带权图, 同一归纳说明

$$(\mathbf{A}^k)_{i,j} = \sum_{i=v_0 \rightarrow v_1 \rightarrow \dots \rightarrow v_k=j} \prod_{r=1}^k w_{v_{r-1}, v_r},$$

即条目是所有长度 k 游走的权重乘积之和, 而不再是游走条数。这个解释依赖通常的加法与乘法; 换用布尔或最小加法运算时, 矩阵幂会回答可达性或固定边数最短成本等不同问题, 不能继续称为计数。

矩阵表示依赖顶点次序。若置换矩阵 $\mathbf{P}$ 改变编号, 同一无向图在新编号下表示为

$$\mathbf{A}' = \mathbf{P}\mathbf{A}\mathbf{P}^\top. \quad (14.3)$$

矩阵元素的位置改变, 连通、环和路径等图性质不应改变。反过来, 并非任意相似变换都只是顶点重编号; 图重编号只允许置换矩阵, 而第 6 章中的一般换基会混合顶点坐标, 通常不再得到同一张离散图。

还可以给每条无向边任取一个方向, 构造**关联矩阵** (incidence matrix) $\mathbf{B} \in \mathbb{R}^{|V| \times |E|}$: 边 $e: i \rightarrow j$ 对应列在 i 处取 1、在 j 处取 -1, 其余为零。反转临时方向只会把该列乘 -1, 不改变后文的 $\mathbf{B}\mathbf{W}\mathbf{B}^\top$ 。邻接矩阵为每对顶点预留位置, 适合稠密线性运算; 邻接表只存每个顶点实际相邻的对象, 空间为 $O(|V| + |E|)$, 更适合稀疏图遍历; 关联矩阵则显式保留“哪条边连接哪些顶点”, 便于表达边差分。在结构边权均非零, 或为邻接矩阵另附边集或掩码时, 三种表示保留同一个图对象, 但直接支持的计算和存储成本不同。

14.1.4 图对象与赋予图的语义必须分开

在贯穿关系图上, 可以为每个顶点放置一元函数 $\phi_i(z_i)$, 并在只考虑一元与成对局部项时为每条边放置成对函数 $\phi_{i,j}(z_i, z_j)$, 形成

$$F(\mathbf{z}) = \bigotimes_{i \in V} \phi_i(z_i) \otimes \bigotimes_{\{i,j\} \in E} \phi_{i,j}(z_i, z_j). \quad (14.4)$$

符号 $\otimes$ 暂时只表示组合局部信息, 第 14.3 节才规定它可能是乘法或加法。若要继续表示式 (13.9) 的原始硬约束, 第四个子句必须保留为三元因子 $\phi_{2,3,4}(z_2, z_3, z_4)$; 式 (14.4) 是同一关系骨架上的成对专门情形, 不是把

三元子句拆成三条边后的等价公式。图说明每个局部项的作用域，却不说明这些函数是否为概率、约束指示、相似度或成本。同一张图既可以计算总权重，也可以寻找最低成本配置；反过来，相同数值表若采用不同作用域，也会产生不同的分解与计算代价。

图不会自动编码条件独立、因果或时间关系；这些语义还需生成规则、分布因子或结构假设。

14.2 遍历、分离与结构分解

14.2.1 遍历把局部邻接组织成可执行次序

广度优先搜索 (breadth-first search, BFS) 从起点 s 出发，先访问距离 s 为一条边的顶点，再访问距离为两条边的顶点。维护一个先进先出队列，并在顶点首次入队时标记它，可以保证每个顶点至多入队一次、每条边至多检查常数次。因此使用邻接表时，时间复杂度为 $O(|V| + |E|)$ ¹。每个非起点顶点首次被发现时记录一条父边，这些父边不成环，并在所有可达顶点上构成一棵搜索树；队列、已访问集合和父边分别回答“接下来处理谁”“谁已处理过”和“如何恢复发现路径”。

对无权图，BFS 首次发现顶点 v 时记录的层数就是从 s 到 v 的最短路径长度。证明按队列层次归纳：处理第 k 层顶点时，所有更短路径的终点已经处理；新发现邻居有一条长度 $k + 1$ 的路径。若它存在更短路径，其倒数第二个顶点应位于更早层，并会更早发现它，产生矛盾。带一般边长时，边数最少不等于总长度最小，BFS 便不再适用。

深度优先搜索 (depth-first search, DFS) 沿一条尚未探索的边持续深入，无法继续时回退。它同样能在线性时间内找连通分量，还能依据进入与退出时间识别有向图中的回边。若 DFS 遇到一条指向当前递归栈内顶点的弧，就得到一个有向环；若没有这种回边，按退出时间逆序排列顶点便得到拓扑序。

拓扑序与有向无环性的等价关系是图论中的基本结构结论²。

定理 14.2 DAG 的拓扑排序 有限有向图存在拓扑序，当且仅当它不含有向环。拓扑序是顶点的一个排列，使每条弧 $i \rightarrow j$ 中 i 都排在 j 之前。

证明. 若存在有向环 $v_1 \rightarrow v_2 \rightarrow \cdots \rightarrow v_k \rightarrow v_1$ ，拓扑序将依次要求 v_1 在 v_2 前、 v_2 在 v_3 前，最终又要求 v_k 在 v_1 前，不可能同时满足。

反过来，设图无有向环。图中必有入度为零的顶点；否则从任意顶点 v 出发，总能选择当前顶点的一条入边 $u \rightarrow v$ ，并反向追溯到其起点 u 。顶点数有限，追溯中必有顶点重复，而重复段按原弧方向组成有向环，产生

¹ T. H. Cormen, C. E. Leiserson, R. L. Rivest, C. Stein, *Introduction to Algorithms*, MIT Press, 2022, 4th ed.

² R. Diestel, *Graph Theory*, Springer, 2017, 5th ed.

矛盾。删除一个入度为零的顶点及其出边，剩余图仍无环。重复这一过程直到图为空，删除次序就是拓扑序。每次若用队列维护新出现的零入度顶点，全部过程只检查每个顶点和每条弧常数次。 ■

拓扑序一般不唯一。两个互相不可达的顶点可以有多种相对次序；这反映偏序未规定它们的先后，而不是算法给出了矛盾答案。

14.2.2 分隔集把全局连接切成局部部分

对无向图，若删除顶点集合 S 及其关联边后，顶点集合 A 与 B 落入不同连通分量，就称 S 将 A 与 B **分隔** (separate)。等价地，从 A 中任一点到 B 中任一点的每条路径都经过 S 。在贯穿图中，集合 $\{2, 3\}$ 分隔 $\{1\}$ 与 $\{4\}$ 。一旦固定 z_2, z_3 的接口信息，只含 z_1 与只含 z_4 的局部项就可以分别处理，再通过接口组合。

删除一个顶点及其关联边后使连通分量数增加的顶点称为割点；删除一条边后使连通分量数增加的边称为桥。贯穿图的每条边都位于某个三角形中，删除该边后仍有连接其两端的替代路径，所以没有桥。删除顶点 1 或 4 后，余图是一个三角形；删除顶点 2 或 3 后，余图分别是路径 $1-3-4$ 或 $1-2-4$ ，仍然连通，所以也没有割点。但删除两个顶点组成的分隔集 $\{2, 3\}$ 会使 1 与 4 断开。桥描述连接冗余，不能单凭边权大小判断。

两两相邻的顶点集合称为**团** (clique)。若它不被更大的团包含，就称为极大团。贯穿图的极大团为

$$\{1, 2, 3\}, \quad \{2, 3, 4\}.$$

“极大”表示不能再加入顶点，“最大”则表示顶点数在全部团中最多；两者不应混用。团把所有成对关系集中到同一个局部集合，但大团也意味着局部表需要同时索引更多变量。

14.2.3 消元会制造填充边

要从式 (14.4) 中消去变量 z_i ，必须先组合所有含 z_i 的局部项，再对 z_i 汇总。结果通常成为 $N(i)$ 上一个新的联合函数，所以原本互不相邻的邻居会在中间结果中直接联系。图上把这些邻居补成团，并删除 i ，称为一次**消元** (elimination)；新加入的边称为**填充边** (fill edge)。

对贯穿图采用次序

$$\pi_{\text{good}} = (1, 4, 2, 3).$$

消去 1 时，其尚未消去的邻居 $\{2, 3\}$ 已经相邻；消去 4 时同理。整个过程中，任何顶点被消去时至多有两个尚未消去的邻居，因此不会产生填充边。

若采用

$$\pi_{\text{bad}} = (2, 1, 3, 4),$$

第一步就要把邻居 $\{1, 3, 4\}$ 补成团，加入原图中不存在的边 $\{1, 4\}$ 。图的原始边数没有改变问题的候选空间，但消元次序改变了中间函数必须同时依赖的变量数。

给定消元次序，某一步中尚未消去邻居的最大数量称为该次序的 **诱导宽度** (induced width)。上述两个次序的诱导宽度分别为 2 和 3。若每个变量至多有 q 个取值，作用于 $k+1$ 个变量的稠密局部表最多含 q^{k+1} 项，因此宽度进入指数，而不仅是一个图形美观指标。

14.2.4 弦图用局部消元刻画无长无弦环

长度至少为 4 的环若有一条连接非相邻环顶点的边，这条边称为弦。每个这类环都有弦的图称为**弦图** (chordal graph)。树因没有环而是弦图；四顶点环加入任一对角线后才成为弦图。

若图中任意两个不同顶点都相邻，就称该图为**完全图** (complete graph)。给定顶点集 $U \subseteq V$ ，保留 U 中的顶点以及原图中两个端点都在 U 内的全部边，所得图称为 U 上的**诱导子图** (induced subgraph)，记作 $\mathcal{G}[U]$ 。

若一个顶点的邻居组成团，就称它为**单纯顶点** (simplicial vertex)。按某个次序依次删除顶点时，若每个顶点在剩余图中都是单纯顶点，该次序称为**完美消元序** (perfect elimination ordering)。

引理 14.3 弦图的单纯顶点 每个非空有限弦图都有单纯顶点；若图不是完全图，则有两个互不相邻的单纯顶点。

证明. 对顶点数归纳。完全图中每个顶点都单纯。若图不连通，对两个连通分量分别应用归纳假设，各取一个单纯顶点；不同分量的两个顶点不相邻，并且它们在分量内与全图中的邻域相同。

下面设图连通但不完全。取两个不相邻顶点 a, b ，并取一个按集合包含关系极小的 a - b 分隔集 S ，即对每个 $s \in S$ ，集合 $S \setminus \{s\}$ 都不再分隔 a, b 。先说明 S 是团。记删除 S 后包含 a, b 的分量分别为 C_a, C_b 。这种极小性保证每个 $s \in S$ 在 C_a, C_b 中都各有邻居，否则可以从 S 删去 s 而仍分隔 a, b 。若 $x, y \in S$ 不相邻，分别在 $C_a \cup \{x, y\}$ 与 $C_b \cup \{x, y\}$ 中取从 x 到 y 的最短路径。两条路径合成长度至少为 4 的环；路径最短性排除同侧的弦，两个分量之间没有边，而 x, y 也不相邻，故该环无弦，产生矛盾。因此 S 是团。

对任一 $C \in \{C_a, C_b\}$ ，诱导子图 $\mathcal{G}[C \cup S]$ 是顶点更少的弦图。若它是完全图，任取 C 中顶点即为该诱导子图的单纯顶点；若它不完全，归纳假设给出两个互不相邻的单纯顶点，而 S 是团，所以至少一个位于 C 。取这个

位于 C 的顶点 v_C 。顶点 v_C 在原图中没有 $C \cup S$ 之外的邻居，故仍是原图的单纯顶点。分别从 C_a, C_b 取得的两个顶点互不相邻，结论成立。 ■

定理 14.4 弦图与完美消元序 有限无向图是弦图，当且仅当它具有完美消元序。

证明. 若图为弦图，引理 14.3 给出一个单纯顶点。删除该顶点得到的诱导子图仍为弦图，故可重复应用引理；依次删除的顶点组成完美消元序。

反过来，设图有完美消元序但含一个长度至少为 4 的无弦环。取环上最早被消去的顶点 v 。此时它的两个环上邻居都尚未消去；无弦性说明这两个邻居不相邻，所以 v 在剩余图中不是单纯顶点，与完美消元序的定义矛盾。 ■

这个判据还给出消元接口：任一消元次序加入全部填充边后都会得到弦图，而该次序在所得弦图中成为完美消元序。

贯穿图本来就是弦图。次序 π_{good} 是完美消元序，因为顶点 1, 4 各自的剩余邻域都是团 $\{2, 3\}$ 。次序 π_{bad} 不是原图的完美消元序；补上边 $\{1, 4\}$ 后，它才成为完成图的完美消元序。弦图不是说消元计算代价一定小，大团仍可使宽度很大。

14.2.5 树分解把一般图组织成相互一致的局部袋

树分解 (tree decomposition) 由一棵树 $\mathcal{T}$ 及每个树顶点 t 对应的顶点袋 $B_t \subseteq V$ 组成，并满足：

1. 每个原图顶点至少出现在一个袋中；
2. 每条原图边的两个端点共同出现在某个袋中；
3. 对任意顶点 i ，所有满足 $i \in B_t$ 的树顶点在 $\mathcal{T}$ 中连通。

第三条称为运行交集条件。它保证一个变量若出现在多个局部袋中，这些副本可以沿树上的连续路径保持一致；仅覆盖全部边而不满足这条条件，不能支持可靠的局部消息传递。

引理 14.5 树上连通子树的 Helly 性质 设 $\mathcal{T}_1, \dots, \mathcal{T}_m$ 是有限树 $\mathcal{T}$ 中的非空连通子树。若任意两棵子树都有公共顶点，则全部子树有公共顶点：

$$\mathcal{T}_i \cap \mathcal{T}_j \neq \emptyset \quad (1 \leq i, j \leq m) \implies \bigcap_{i=1}^m \mathcal{T}_i \neq \emptyset.$$

证明. 在 $\mathcal{T}$ 中任选根。对每棵 $\mathcal{T}_i$, 令 a_i 为其中离根最近的顶点。若最近顶点不唯一, 或 a_i 不在根到某个 $x \in \mathcal{T}_i$ 的路径上, 则连接这两个子树顶点的唯一路径会经过一个离根更近的顶点; 连通子树包含这条路径, 产生矛盾。因此 a_i 唯一, 并且位于根到 $\mathcal{T}_i$ 中每个顶点的路径上。取深度最大的 a_k 。

固定任意 i 。由两两相交, 可取 $x \in \mathcal{T}_i \cap \mathcal{T}_k$ 。顶点 a_i, a_k 都在从根到 x 的路径上, 而 a_k 的深度不小于 a_i , 所以 a_k 位于 a_i 到 x 的路径上。 $\mathcal{T}_i$ 连通且含 a_i, x , 必包含二者之间的整条路径, 因而 $a_k \in \mathcal{T}_i$ 。这对每个 i 都成立, 故 a_k 属于全部子树。 ■

这个引理补上了团与袋之间的关键一步。对原图顶点 v , 记 $\mathcal{T}_v = \{t : v \in B_t\}$ 。运行交集条件说明 $\mathcal{T}_v$ 是连通子树; 若 u, v 相邻, 边覆盖条件又说明 $\mathcal{T}_u \cap \mathcal{T}_v \neq \emptyset$ 。因此, 对任意团 C , $\{\mathcal{T}_v : v \in C\}$ 两两相交。由引理 14.5, 存在同一个树顶点 t 属于所有这些子树, 也就是 $C \subseteq B_t$ 。所以大小为 r 的团给出树宽下界 $r - 1$ 。

贯穿图有树分解

$$B_a = \{1, 2, 3\}, \quad B_b = \{2, 3, 4\},$$

其中让 $B_a - B_b$ 连接成一条树。顶点 2, 3 各出现在两个袋中且这些袋连通, 顶点 1, 4 各出现一次。每条边也被某个袋覆盖。

树分解的宽度定义为

$$\max_t |B_t| - 1.$$

减一使树的树宽为 1, 单个顶点图的树宽为 0。图的 **树宽** (treewidth) 是所有树分解宽度的最小值。贯穿图含三角形; 刚才的团下界说明任何树分解都必须在某个袋中同时容纳三角形的三个顶点, 所以树宽至少为 2。上述分解的两个袋大小均为 3, 宽度达到 2, 故贯穿图的树宽恰为 2。

定理 14.6 消元序产生树分解 给定有限无向图及一个完整消元次序。若顶点 v 被消去时尚未消去的邻居集合为 $N_\pi^+(v)$, 并在消元时把它们补成团, 则存在袋

$$B_v = \{v\} \cup N_\pi^+(v)$$

组成的树分解, 其宽度不超过该次序的诱导宽度。因而图的树宽不大于任一消元次序的诱导宽度。

证明. 在完成消元后得到的弦图中, 每个 $N_\pi^+(v)$ 都是团。对每个非空 $N_\pi^+(v)$, 令 $p(v)$ 是该集合中最早被消去的顶点, 并连接袋 B_v 与 $B_{p(v)}$; 若集合为空,

则把对应袋作为一个根。若原图不连通, 可以把各棵所得树任意连接, 空交集不会破坏条件。

每条连接都从较早消去顶点指向较晚消去顶点, 所以不可能形成有向环; 除根外每个袋恰有一个父袋, 因而得到树。每个顶点 v 属于自己的袋。若原图边 $\{u, v\}$ 中 u 先被消去, 则 $v \in N_{\pi}^+(u)$, 所以该边被 B_u 覆盖。

还需验证运行交集。固定顶点 z 。若 $z \in B_v$ 且 $v \neq z$, 则 $z \in N_{\pi}^+(v)$ 。由于该集合已补成团, z 与 $p(v)$ 相邻; 若 $p(v) \neq z$, 则 $z \in B_{p(v)}$ 。因此从任一含 z 的袋沿父边向上走, 在到达 B_z 之前经过的每个袋都仍含 z 。全部含 z 的袋于是连成子树。

最后, $|B_v| - 1 = |N_{\pi}^+(v)|$, 最大袋宽不超过该消元次序的诱导宽度。■

反方向也成立: 宽度为 k 的树分解可通过依次删除叶袋中特有顶点, 构造诱导宽度不超过 k 的消元次序。证明维持如下不变量: 每轮开始时, 剩余袋构成当前填充图的树分解, 而不只覆盖原图。初始时这正是给定树分解。先删除被相邻袋包含的冗余叶袋; 对剩余叶袋 B_{ℓ} 及其父袋 B_p , 集合 $X = B_{\ell} \setminus B_p$ 非空。运行交集条件说明 X 中的顶点只出现在 B_{ℓ} , 再由当前填充图的边覆盖条件可知, 这些顶点的尚存邻居都位于 B_{ℓ} 。

依次消去 X 中的顶点时, 新填充边的两个端点仍在 B_{ℓ} 中, 故继续被该袋覆盖; 从袋中删去已消顶点也不破坏其余顶点的运行交集。因此不变量在消元过程中保持, 且每个被消顶点的尚存邻居数至多为 $|B_{\ell}| - 1 \leq k$ 。当 X 删空后, 叶袋只剩接口 $B_{\ell} \cap B_p$, 其中的边也由父袋 B_p 覆盖, 因而可以移除该叶袋并保持不变量。重复到只剩根袋, 再以任意次序消去根袋。由此, 树宽等于所有消元次序的最小诱导宽度。寻找最优次序本身通常很难, 实践中常用最小度数或最少填充边等启发式, 并把所得宽度作为可计算上界。

14.3 分配律与动态规划的代数

14.3.1 共享子问题依靠分配律避免重复枚举

考虑贯穿图上的表达式 (14.4)。若要汇总全部赋值, 直接写成

$$Z = \bigoplus_{z_1, \dots, z_4} F(\mathbf{z}).$$

变量 z_1 只通过接口 (z_2, z_3) 与其余变量联系, 因此可以先计算

$$m_{1 \rightarrow \{2,3\}}(z_2, z_3) = \bigoplus_{z_1 \in \mathcal{Z}_1} \phi_1(z_1) \otimes \phi_{1,2}(z_1, z_2) \otimes \phi_{1,3}(z_1, z_3). \quad (14.5)$$

对每个接口赋值 (z_2, z_3) ，这个局部结果只需计算一次。变量 z_4 一侧可得到同形消息 $m_{4 \rightarrow \{2,3\}}(z_2, z_3)$ ，最终只需在接口上组合两条消息和其余局部项。

这一步合法，不是因为图画成树枝形，而是因为 $\otimes$ 对 $\oplus$ 满足分配律。若把与 z_1 无关、但可以依赖接口值的项记为 $c(z_2, z_3)$ ，则

$$\bigoplus_{z_1} (c(z_2, z_3) \otimes g(z_1, z_2, z_3)) = c(z_2, z_3) \otimes \left(\bigoplus_{z_1} g(z_1, z_2, z_3) \right).$$

图说明哪些项与 z_1 无关，代数规则则允许把它们移出汇总。动态规划的核心就是保存接口变量上的局部结果，使后续不同部分复用同一个子问题答案。

树上的消息可以把这一直觉写成精确不变量。先考虑一棵树，并在顶点与边上分别放置 $\phi_i(z_i)$ 和 $\phi_{i,j}(z_i, z_j)$ 。删除边 $\{u, v\}$ 后，记包含 u 的连通分量为 $T_{u|v}$ 。从 u 发给 v 的消息定义为

$$m_{u \rightarrow v}(z_v) = \bigoplus_{z_{T_{u|v}}} \left[\bigotimes_{i \in T_{u|v}} \phi_i(z_i) \otimes \bigotimes_{\substack{\{i,j\} \in E \\ i,j \in T_{u|v}}} \phi_{i,j}(z_i, z_j) \otimes \phi_{u,v}(z_u, z_v) \right]. \quad (14.6)$$

这里消息的自变量只有接口值 z_v ，被汇总的范围则是整棵 u 侧子树。

定理 14.7 树消息递推 在有限树和交换半环上，式 (14.6) 满足

$$m_{u \rightarrow v}(z_v) = \bigoplus_{z_u} \left[\phi_u(z_u) \otimes \phi_{u,v}(z_u, z_v) \otimes \bigotimes_{r \in N(u) \setminus \{v\}} m_{r \rightarrow u}(z_u) \right]. \quad (14.7)$$

证明. 对子树 $T_{u|v}$ 的顶点数归纳。若 u 是叶顶点，乘积中没有入消息，递推式正是对 z_u 汇总顶点项与接口边项。若 u 还有邻居 $r \neq v$ ，删除 u 后各 $T_{r|u}$ 互不相交，且它们之间没有边。归纳假设把每棵子树的全部局部项概括为 $m_{r \rightarrow u}(z_u)$ 。结合律和交换律把这些子树分组，分配律再把只依赖 z_u, z_v 的项移到各子树汇总之外，便得到式 (14.7)。 ■

定理依赖树在删边后确实分成互不重叠的子树。一般有环图若直接沿原边反复发送同形消息，同一局部项可能经不同方向重复返回；要得到精确结果，须先消元或构造满足运行交集的树分解。

14.3.2 半环抽取局部计算真正需要的规则

半环 (semiring) $(\mathcal{S}, \oplus, \otimes, e_\oplus, e_\otimes)$ 由一个集合、两种运算和两个单位元组

成。本章使用交换半环，它满足：

1. $\oplus$ 结合、交换，单位元为 $e_{\oplus}$ ；
2. $\otimes$ 结合、交换，单位元为 $e_{\otimes}$ ；
3. $\otimes$ 对 $\oplus$ 分配；
4. $e_{\oplus}$ 对 $\otimes$ 具有吸收性， $a \otimes e_{\oplus} = e_{\oplus}$ 。

半环不要求每个元素有加法逆元或乘法逆元。动态规划通常只需要组合、汇总和分配，不需要做减法或除法。

三种与本章直接相关的半环为：

用途	$\mathcal{S}$	$\oplus$	$\otimes$	$(e_{\oplus}, e_{\otimes})$
总权重	$\mathbb{R}_{\geq 0}$	+	$\times$	$(0, 1)$
最大权重	$\mathbb{R}_{\geq 0}$	max	$\times$	$(0, 1)$
最小成本	$\mathbb{R} \cup \{+\infty\}$	min	+	$(+\infty, 0)$

最大积中0既是max的单位元，也是乘法吸收元。最小加法中 $+\infty+c = +\infty$ ，所以 $+\infty$ 表示不可行路径或赋值。若最大积取对数，还可得到 $(\max, +)$ 半环，其汇总单位元为 $-\infty$ 、组合单位元为0。

布尔半环 $(\{\text{false}, \text{true}\}, \vee, \wedge)$ 则计算是否存在可行赋值。同一个图结构因此能够回答“总共有多少权重”“最佳配置是什么”“是否存在配置”等不同查询。结构相同不表示答案相同；运算是问题定义的一部分。

一个两变量小表可以直接核对运算改变了什么。令

		$y = 0$	$y = 1$
$g(x, y) =$	$x = 0$	1	3
	$x = 1$	2	4

把四个表项视为非负权重时，和积查询给出 $\sum_{x,y} g(x, y) = 10$ ，最大积查询在这里只有一个局部因子，给出 $\max_{x,y} g(x, y) = 4$ 及见证 $(1, 1)$ 。把同一组数字改解释为成本，最小加法查询给出 $\min_{x,y} g(x, y) = 1$ 及见证 $(0, 0)$ 。这三个答案来自同一作用域，却对应不同问题；数值表本身不能决定应选哪一种半环。

14.3.3 变量消除在任意交换半环上复用同一结构

设每个局部因子取值于半环 $\mathcal{S}$ 。给定消元次序，每次收集所有含变量 z_i 的因子，先用 $\otimes$ 组合，再对 z_i 用 $\oplus$ 汇总，得到作用于剩余邻居的新因子。算

法重复到不再有变量，就得到全局半环和

$$Z = \bigoplus_{z \in Z_1 \times \dots \times Z_4} \left[\bigotimes_i \phi_i(z_i) \otimes \bigotimes_{\{i,j\} \in E} \phi_{i,j}(z_i, z_j) \right]. \quad (14.8)$$

定理 14.8 半环变量消除的正确性 在有限变量、交换半环和式 (14.4) 的局部分解下，按任意完整次序执行上述变量消除，所得结果等于式 (14.8) 的直接枚举值。

证明. 证明维持一个不变量：每次消元后，当前因子的半环乘积再对剩余变量汇总，等于原表达式对已消与未消变量的全局汇总。初始时该命题就是式 (14.8)。

设下一变量为 z_i ，把当前因子分成含 z_i 的集合 $\mathcal{F}_i$ 和不含它的集合 $\mathcal{F}_{-i}$ 。有限性、结合律与交换律允许重排有限汇总，分配律给出

$$\begin{aligned} & \bigoplus_{z_{-i}} \bigoplus_{z_i} \left[\left(\bigotimes_{f \in \mathcal{F}_{-i}} f \right) \otimes \left(\bigotimes_{f \in \mathcal{F}_i} f \right) \right] \\ &= \bigoplus_{z_{-i}} \left[\left(\bigotimes_{f \in \mathcal{F}_{-i}} f \right) \otimes \left(\bigoplus_{z_i} \bigotimes_{f \in \mathcal{F}_i} f \right) \right]. \end{aligned}$$

括号中的最后一项正是算法生成的新因子，所以消去 z_i 后不变量保持。归纳到所有变量消去，剩余标量等于直接枚举值。 ■

定理说明消元次序不改变精确答案，却会改变中间因子的作用域。若所有变量取值数不超过 q ，某次序诱导宽度为 k ，稠密表实现的时间通常含 $O(|V|q^{k+1})$ 量级，空间含 $O(|V|q^k)$ 量级；具体常数还取决于因子数和存储方式。树宽小使指数只依赖局部宽度，不代表变量取值很大或因子计算昂贵时成本一定低。

14.3.4 和积、最大积与最小加法改变所求答案

若 ϕ 是非负权重，选择和积半环得到总权重 Z 。固定某个变量值而汇总其余变量，可以得到未归一化边缘权重；若这些权重来自概率模型，还需除以总权重并核对分布定义。半环公式本身只计算非负数，不自动赋予概率解释。

改用最大积半环，

$$M = \max_z \prod_i \phi_i(z_i) \prod_{\{i,j\} \in E} \phi_{i,j}(z_i, z_j)$$

得到最佳权重。若还要恢复最优配置，每次局部最大化必须保存达到最大值的 z_i 选择，最后按消元逆序回溯。只保存最大值会丢掉见证赋值；并列最大值时，还应说明返回任一个、全部，还是采用固定平局规则。

若局部量是成本 $c_i, c_{i,j}$ ，采用最小加法半环得到

$$C^* = \min_z \left[\sum_i c_i(z_i) + \sum_{\{i,j\} \in E} c_{i,j}(z_i, z_j) \right].$$

这与最大积取负对数的形式相近，但只有权重为正并且对数变换保持目标次序时才能对应。零权重映为无穷成本，负权重则不能直接取实对数。

最短路需要先说明在哪一类对象上优化。记 $\mathcal{P}_{s,v}$ 为从 s 到 v 的简单路径集合， $\mathcal{W}_{s,v}$ 为允许重复顶点和边的有限游走集合，并约定空集上的最小值或下确界为 $+\infty$ 。对应的两个量为

$$d_{\text{path}}(s, v) = \min_{P \in \mathcal{P}_{s,v}} \ell(P), \quad d_{\text{walk}}(s, v) = \inf_{W \in \mathcal{W}_{s,v}} \ell(W).$$

有限图中的简单路径只有有限条，所以目标可达时 d_{path} 总能由某条路径达到。游走可以反复绕环，因而 d_{walk} 可能为 $-\infty$ 。若不存在从 s 可达且还能到达 v 的负环，则可以从任意游走中删除非负闭合段而不增加长度，最终得到简单路径，所以两个量相等；若存在这样的负环，则 $d_{\text{walk}}(s, v) = -\infty$ ，而简单路径最小值仍是有限条候选中的最小值。

标准最短路算法通常求游走下确界。先假设不存在从 s 可达的负环，此时每个有限下确界都可由简单路径见证。把从起点 s 到顶点 v 的距离记为 $D(v)$ 。空游走给出起点边界 $D(s) = 0$ ；若 v 从 s 不可达，则约定 $D(v) = +\infty$ 。对其余顶点，每条非空路径都可按最后一条边 $u \rightarrow v$ 分组，于是得到 Bellman 最优性关系

$$D(s) = 0, \quad D(v) = \min_{u \rightarrow v} \{D(u) + \ell_{u,v}\} \quad (v \neq s), \quad (14.9)$$

其中空前驱集合上的最小值为 $+\infty$ ，并约定 $+\infty + c = +\infty$ 。这些约定使不可达顶点无需另写例外分支。

在 DAG 上，式 (14.9) 确实给出一次递推。先令 $D(s) = 0$ 、其余顶点为 $+\infty$ ，再按拓扑序处理顶点 v ，用所有入边计算

$$D(v) \leftarrow \min \left\{ D(v), \min_{u \rightarrow v} (D(u) + \ell_{u,v}) \right\}.$$

当处理 v 时，它的全部前驱已经处理。任意到达 v 的非空路径都以某条 $u \rightarrow v$ 结束，而每个候选 $D(u) + \ell_{u,v}$ 也对应一条实际路径；对拓扑序归纳便知更新后的 $D(v)$ 恰为最短距离。不可达顶点的所有候选仍为 $+\infty$ ，因此保持不可达。每条边只参与一次松弛，路径与游走也因无环而没有区别。

一般有环图不能把 Bellman 式按任意顶点次序只计算一遍, 因为一个前驱的值可能稍后继续下降。甚至在没有负环时, 循环固定点方程本身也可能有多组解。例如加入从 s 到 a 的长度 5 边以及 a, b 之间长度均为 0 的双向边后, 任意 $D(a) = D(b) \leq 5$ 都满足局部等式, 但真正最短距离是 5。算法还必须规定从 $+\infty$ 开始的松弛过程, 而不能只写固定点方程。

为处理尚不知道是否存在负环的一般输入, 改用迭代标签而不预先称其为真实距离。令 $L^{(0)}(s) = 0$, 对 $v \neq s$ 令 $L^{(0)}(v) = +\infty$, 并递推

$$L^{(k)}(v) = \min \left\{ L^{(k-1)}(v), \min_{u \rightarrow v} (L^{(k-1)}(u) + \ell_{u,v}) \right\}.$$

对 k 归纳可知, $L^{(k)}(v)$ 是使用至多 k 条边到达 v 的最小游走长度。若不存在从 s 可达的负环, 则每个有限最短距离都有至多 $|V| - 1$ 条边的简单路径见证, 故 $|V| - 1$ 轮足够; 这正是 Bellman-Ford 松弛的基础。若某个从 s 可达的负环还能到达目标 v , 则 $L^{(k)}(v)$ 会因反复绕环而无下界, 真实游走下确界为 $-\infty$, 不存在有限的 Bellman 距离。下一节将分别说明非负边长怎样支持 Dijkstra 的贪心次序, 以及怎样先用额外一轮松弛找到可达负环的证据, 再沿有向边传播其影响。

14.3.5 求和与取最大混用时不能任意换序

同一种 $\oplus$ 在有限变量间可以交换次序, 但不同汇总运算通常不能。取

		$y = 0$	$y = 1$
$h(x, y) =$	$x = 0$	4	0
	$x = 1$	0	4

若先对每个 x 把 y 求和, 再选同一个 x , 则

$$\max_x \sum_y h(x, y) = 4. \quad (14.10)$$

若允许每个 y 分别选择最好的 x , 则

$$\sum_y \max_x h(x, y) = 8. \quad (14.11)$$

两个值不同, 因为第二个查询允许选择随 y 变化, 而第一个查询要求在看到或汇总 y 之前固定同一个 x 。

一般总有

$$\max_x \sum_y h(x, y) \leq \sum_y \max_x h(x, y),$$

因为对任意固定 x , 每一项 $h(x, y)$ 都不超过 $\max_{x'} h(x', y)$; 再对 x 取最大仍保持不等式。等号需要存在一个共同的 x 同时所有相关 y 上达到最

大，不能只凭分配律假定。

因此，含求和变量与最大化变量的查询不仅由图和树宽决定，还由允许的消元次序决定。受约束次序可能比普通树宽宽得多。把边缘概率、最可能联合配置和边缘最大化混称为一次“推断”，会掩盖它们不同的查询目标和计算边界。

前述交换与分配论证针对有限汇总。把 $\oplus$ 换成连续积分时，还需第2.8节的 Tonelli 或 Fubini 条件：非负可测函数可用 Tonelli 交换积分，带符号函数通常需要绝对可积。仅仅把有限和积公式中的求和号改成积分号，不能保证积分存在或允许换序。类似地，树消息的精确性来自无环分解；在原始环图上运行局部传播可以成为近似算法，但其收敛与误差不由半环公理自动保证。

14.4 图上的精确与近似求解

14.4.1 最短路算法依赖边长条件

给有向或无向图的每条边指定实边长 ℓ_e 。本节的单源距离采用上文的 $d_{\text{walk}}(s, v)$ ；距离有限时，它等于简单路径最小值。若所有边长非负，Dijkstra 算法维护已确定集合 S 和暂定距离 $D(v)$ ：每次选择 S 外暂定距离最小的顶点 u ，把它加入 S ，再尝试用 $D(u) + \ell_{u,v}$ 改善邻居³。

定理 14.9 Dijkstra 算法的贪心正确性 若所有边长非负，则顶点 u 被选入已确定集合时，暂定距离 $D(u)$ 等于从 s 到 u 的游走下确界，也等于简单路径最小值。

证明. 对选入次序归纳。起点距离为零，结论成立。假设此前选入顶点均已正确，考虑新选入的 u 。若存在更短路径 P ，沿 P 从 s 前进，令 y 为第一个尚未进入 S 的顶点， x 为它在路径上的前驱。归纳假设给出 $D(x)$ 已经等于最短距离；处理 x 时，松弛保证

$$D(y) \leq D(x) + \ell_{x,y},$$

不超过路径 P 到达 y 的前缀长度。由于剩余边长非负，该前缀长度不超过 P 到 u 的总长度。算法又因 u 的暂定距离最小而有 $D(u) \leq D(y)$ 。于是 $D(u)$ 不超过假设中的更短路径长度，与 $D(u)$ 始终由某条实际路径产生、不能低于最短距离矛盾。 ■

非负性用在“路径前缀不会比总长度更大”这一步。存在负边时，一个已确定顶点可能在后面通过负边得到更低成本，贪心结论失效。Bellman-Ford 算法反复松弛全部边；经过 $|V| - 1$ 轮后，它能得到所有不受相关负环影

³ T. H. Cormen, C. E. Leiserson, R. L. Rivest, C. Stein, *Introduction to Algorithms*, MIT Press, 2022, 4th ed.

响的有限距离。接着检查一轮所有边：若 $L(u) < +\infty$ 且 $L(u) + \ell_{u,v} < L(v)$ ，就把可继续改善的端点 v 记为受影响种子。这一轮只检测从 s 可达的负环证据，尚未标出全部受影响目标；还要从所有种子出发沿有向边做一次可达性遍历，所有遍历到的顶点的游走下确界均为 $-\infty$ 。对特定目标 v ，只有某个负环既能从 s 到达、又能沿有向路径到达 v 时， $d_{\text{walk}}(s, v)$ 才等于 $-\infty$ 。若负环从 s 可达却不能到达 v ，它不改变 v 的距离；若负环本身不能从 s 到达，它不影响任何单源查询。检测到负环、目标距离无有限值与简单路径最小值仍存在，是三个不同判断。

例如取弧长

$$\ell_{s,a} = 2, \quad \ell_{s,b} = 5, \quad \ell_{a,b} = 1, \quad \ell_{a,t} = 5, \quad \ell_{b,t} = 2.$$

Dijkstra 算法先确定 $D(a) = 2$ ，经 a 把 $D(b)$ 从 5 改为 3；随后确定 b ，再把 $D(t)$ 从 7 改为 5。最短路为 $s \rightarrow a \rightarrow b \rightarrow t$ ，长度 $2 + 1 + 2 = 5$ 。这个手算展示的是非负边长下的确定次序；若把 $\ell_{a,b}$ 改成负数，算出的某条路径仍可验证，却不能继续用定理 14.9 保证贪心确定步骤。

14.4.2 最小生成树连接全部顶点而不优化点对距离

在连通无向加权图中，**生成树** (spanning tree) 包含全部顶点并且是一棵树。**最小生成树** (minimum spanning tree, MST) 使所选 $n - 1$ 条边的总权重最小。它优化全局连接成本，不要求任意两点在树上的路径仍是原图最短路。

MST 贪心算法依据割性质。对任意非平凡顶点划分 $(S, V \setminus S)$ ，跨越该割的最轻边称为轻边。

引理 14.10 最小生成树的割性质 若边集合 A 包含在某棵最小生成树中，且割 $(S, V \setminus S)$ 不切断 A 中的任何边，则跨割的一条轻边 e 也可以与 A 共同包含在某棵最小生成树中。

证明. 取一棵包含 A 的最小生成树 T 。若 $e \in T$ ，结论已成立。否则把 e 加入 T 会形成唯一环。这个环还必须通过另一条跨割边 f ，否则无法从割的一侧经 e 返回同侧。由于 e 是轻边， $w_e \leq w_f$ 。删除 f 得到新生成树 $T' = T + e - f$ ，其总权重不大于 T ，故仍为最小生成树。割不切断 A 中的边，所以 $f \notin A$ ，新树仍包含 A 。 ■

Kruskal 算法按边权从小到大的扫描，只加入连接不同当前分量的边；Prim 算法则从一个已连通顶点集出发，反复加入跨当前割的轻边。二者都可逐步应用引理 14.10，但维护的割不同。边权并列时 MST 可能不唯一，最小总权重仍唯一确定。

14.4.3 最大流与最小割给出容量证书

在带源点 s 、汇点 t 的有向网络中，每条弧有非负容量 $c_{i,j}$ 。流 (flow) $f_{i,j}$ 满足

$$0 \leq f_{i,j} \leq c_{i,j},$$

并且除 s, t 外每个顶点流入等于流出。流值 $|f|$ 是源点净流出量。一个 s - t 割由包含 s 但不含 t 的集合 S 确定，容量为

$$c(S, V \setminus S) = \sum_{\substack{i \in S \\ j \notin S}} c_{i,j}.$$

任意流值都不超过任意割容量，因为对 S 内顶点的流守恒式求和，内部流相消，跨割净流出等于 $|f|$ ，而正向流出不超过正向容量、反向流入非负。

定理 14.11 最大流最小割定理 在有限非负容量网络中，最大 s - t 流值等于最小 s - t 割容量。

证明. 可行流集合由有限个闭有界线性约束定义，非空且紧，因此连续的流值函数能达到最大值。取一个最大流 f 。构造残量网络：弧 $i \rightarrow j$ 有剩余容量 $c_{i,j} - f_{i,j}$ ，并为已发送的流加入容量 $f_{i,j}$ 的反向弧。若残量网络中存在从 s 到 t 的路径 P ，令 $\delta > 0$ 为路径上最小剩余容量。沿 P 更新原流：经过原弧 $i \rightarrow j$ 对应的正向残量弧时令 $f_{i,j} \leftarrow f_{i,j} + \delta$ ，经过该原弧对应的反向残量弧时令 $f_{i,j} \leftarrow f_{i,j} - \delta$ 。瓶颈值的定义保证正向更新不超过容量、反向更新不低于零；路径内部每个顶点的一次流入变化与一次流出变化相消，所以流量守恒保持，而源点净流出量增加 δ 。这便得到更大可行流，与最大性矛盾。

令 S 为残量网络中从 s 可达的顶点集合。于是 $s \in S, t \notin S$ 。对每条从 S 到补集的原弧，剩余容量必须为零，否则终点也可达，所以 $f_{i,j} = c_{i,j}$ 。对每条从补集进入 S 的原弧，其反向残量容量必须为零，所以 $f_{i,j} = 0$ 。因此跨割净流出恰等于

$$|f| = \sum_{\substack{i \in S \\ j \notin S}} c_{i,j} = c(S, V \setminus S).$$

前面的弱上界说明没有流能超过任何割；现在一个最大流与一个割达到同一值，二者分别最优。 ■

残量网络同时给出最优性证书。对整数容量，沿整数瓶颈增广可得到整数最大流。对有理容量或机器有限精度容量，容量具有有限比特编码，可以采用具有有限步复杂度保证的最大流算法，并把位运算成本计入输入长度。对任意数学实数，定理仍由紧性论证保证最优流和最小割存在；若没

有给出这些实数的有限有效表示或精确运算接口，就不能进一步声称程序能够精确输出最优解。

一个整数网络可以同时展示增广与证书。令

$$c_{s,a} = 3, \quad c_{s,b} = 2, \quad c_{a,b} = 1, \quad c_{a,t} = 2, \quad c_{b,t} = 3.$$

依次沿 $s \rightarrow a \rightarrow t$ 、 $s \rightarrow b \rightarrow t$ 和 $s \rightarrow a \rightarrow b \rightarrow t$ 增广 2, 2, 1 单位，得到流值 5。此时割 $S = \{s\}$ 的容量为 $c_{s,a} + c_{s,b} = 5$ ，所以弱上界已经达到：无需枚举其他流，便可由“可行流值 5+ 割容量 5”认证二者分别为最大流和最小割。

14.4.4 二部匹配是流的一个精确特例

二部图 $\mathcal{G} = (U, W, E)$ 中的**匹配** (matching) 是一组互不共享端点的边。要求边数最大的匹配称为最大匹配。建立源点到每个 $u \in U$ 容量为 1 的弧，把每条 $\{u, w\} \in E$ 改为容量 1 的弧 $u \rightarrow w$ ，再从每个 $w \in W$ 连容量 1 的弧到汇点。任一整数流值为 k 对应 k 条匹配边，反之亦然。整数容量的最大流存在整数最优解，所以二部最大匹配可由最大流精确求得。

匹配语言中的**增广路径** (augmenting path) 是一条端点尚未匹配、边在“未匹配”与“已匹配”之间交替出现的路径。沿它翻转两类边会使匹配大小增加 1。在上述流网络中，这正对应一条残量 s - t 路径；不存在增广路径时，残量割给出最大性的证书。这个接口只说明基数二部匹配与单位容量流的对应，不涵盖一般图匹配所需的奇环处理。

非二部图的奇环会使这个简单流构造失效，加权匹配又改变目标。“可画成图”不足以选择算法，还要核对图类别、约束与优化目标。

14.4.5 树宽小使局部动态规划精确可行

树分解上的动态规划为每个袋维护接口赋值的最优值或总权重。以贯穿图为例，叶袋 $\{1, 2, 3\}$ 向袋 $\{2, 3, 4\}$ 发送关于接口 (z_2, z_3) 的表；后一袋组合消息与含 z_4 的局部项，再完成余下汇总。运行交集条件保证某变量在不同袋中的出现沿树保持一致。

若树宽为 k 、每个变量至多有 q 个取值，袋表规模至多为 q^{k+1} 。这与第 14.2 节的诱导宽度分析是同一局部表成本，此处不再重复按全部变量数枚举候选。固定 k 时，动态规划关于顶点数为多项式时间； k 随顶点数增长时，这一保证不再成立。

14.4.6 二值成对次模能量可以精确转成最小割

现在回到第13.3节留下的二值离散目标。设 $z_i \in \{0, 1\}$, 能量为

$$\mathcal{E}(\mathbf{z}) = \sum_i D_i(z_i) + \sum_{\{i,j\} \in E} \theta_{i,j}(z_i, z_j). \quad (14.12)$$

这里用 $\mathcal{E}$ 表示能量函数, E 仍专指图的边集合。成对项若满足

$$\theta_{i,j}(0, 0) + \theta_{i,j}(1, 1) \leq \theta_{i,j}(0, 1) + \theta_{i,j}(1, 0), \quad (14.13)$$

就称该二值成对项为次模。它限制四个配置的相对组合, 并不要求相同标签的两个能量分别都小于不同标签能量。

定理 14.12 二值次模成对能量的割表示 若式 (14.12) 中所有一元项和成对项均为有限实数, 且每个成对项满足式 (14.13), 则存在非负容量的 s - t 网络, 使每个二值配置对应一个割, 割容量等于该配置能量加同一个常数。因而一次最小割给出全局最优配置。

证明. 固定一条边并简写 $\theta_{a,b} = \theta_{i,j}(a, b)$ 。令

$$w_{i,j} = \frac{\theta_{0,1} + \theta_{1,0} - \theta_{0,0} - \theta_{1,1}}{2}, \quad (14.14)$$

$$\alpha_i = \theta_{1,0} - \theta_{0,0} - w_{i,j}, \quad \alpha_j = \theta_{0,1} - \theta_{0,0} - w_{i,j}. \quad (14.15)$$

次模不等式恰好保证 $w_{i,j} \geq 0$ 。逐一代入四种二值配置可验证

$$\theta_{i,j}(z_i, z_j) = \theta_{0,0} + \alpha_i z_i + \alpha_j z_j + w_{i,j} |z_i - z_j|. \quad (14.16)$$

具体地,

$$\begin{aligned} (0, 0) : \quad & \theta_{0,0} = \theta_{0,0}, \\ (1, 0) : \quad & \theta_{0,0} + \alpha_i + w_{i,j} = \theta_{1,0}, \\ (0, 1) : \quad & \theta_{0,0} + \alpha_j + w_{i,j} = \theta_{0,1}, \\ (1, 1) : \quad & \theta_{0,0} + \alpha_i + \alpha_j = \theta_{1,1}, \end{aligned}$$

其中最后一个等式使用 $2w_{i,j} = \theta_{0,1} + \theta_{1,0} - \theta_{0,0} - \theta_{1,1}$ 。式中的 $\theta_{0,0}$ 可并入总常数, 线性项并入相应一元函数。对所有边重复后, 能量写成

$$C + \sum_i D'_i(z_i) + \sum_{\{i,j\} \in E} w_{i,j} |z_i - z_j|.$$

一元值可能为负, 但对每个 i 同时减去 $\min\{D'_i(0), D'_i(1)\}$ 只改变常数, 并使两个值都非负。

建立源点 s 、汇点 t 和每个变量顶点。规定源侧表示 $z_i = 0$ ，汇侧表示 $z_i = 1$ 。加入容量 $D'_i(1)$ 的弧 $s \rightarrow i$ 和容量 $D'_i(0)$ 的弧 $i \rightarrow t$ 。若 i 在源侧，只有 $i \rightarrow t$ 跨割，支付 $D'_i(0)$ ；若在汇侧，只有 $s \rightarrow i$ 跨割，支付 $D'_i(1)$ 。对每个无向成对项 $\{i, j\}$ ，加入两条容量均为 $w_{i,j}$ 的反向弧 $i \rightarrow j$ 与 $j \rightarrow i$ 。当两端同侧时没有弧跨割；当两端异侧时，恰有一条弧从源侧指向汇侧，因而无论 $(z_i, z_j) = (0, 1)$ 还是 $(1, 0)$ ，割容量都增加 $w_{i,j}|z_i - z_j| = w_{i,j}$ 。

因此每个配置的割容量等于 $\mathcal{E}(\mathbf{z}) - C'$ ，其中 C' 与配置无关。每个 s - t 割也唯一规定所有变量位于哪一侧，所以最小割与全局最小能量配置一一对应。 ■

这一结论对有限实值项给出割表示和最优解的存在性。若各项是有理数或机器有限精度数，构造出的容量具有有限编码，因而可调用最大流算法计算最优配置；对没有有效表示的任意实数，只保留存在性结论。二元成对能量可由图割表示的更一般条件见 Kolmogorov 和 Zabih⁴。

取两个变量，令

$$D_1(0) = 0, \quad D_1(1) = 2, \quad D_2(0) = 2, \quad D_2(1) = 0, \quad w_{1,2} = 1.$$

四个配置 $(0, 0), (0, 1), (1, 0), (1, 1)$ 的能量依次为 2, 1, 5, 2。最小割把顶点 1 放在源侧、顶点 2 放在汇侧，只支付二者间容量 1，返回最优配置 $(0, 1)$ 。这个小例子同时核对了终端边的方向。

若式 (14.13) 失败， $w_{i,j} < 0$ ，非负容量割网络不能按上述方式表示该项。多标签能量、含高阶项的能量或一般非次模二次目标也不自动归入一次最小割。某些特殊结构可通过辅助顶点、分层网络或一系列二值子问题处理，但必须分别证明等价性或近似比。

14.4.7 松弛、取整与搜索需要报告界

精确结构不存在时，可以把二值约束 $z_i \in \{0, 1\}$ 放宽为 $z_i \in [0, 1]$ ，但扩大定义域还不足以定义松弛问题。记原离散可行集为 $\mathcal{Z}$ ，还需同时给出包含它的连续可行域 $\tilde{\mathcal{Z}} \supseteq \mathcal{Z}$ ，以及连续域上的目标延拓 $\tilde{\mathcal{E}}$ ，并要求

$$\tilde{\mathcal{E}}(\mathbf{z}) = \mathcal{E}(\mathbf{z}) \quad (\mathbf{z} \in \mathcal{Z}).$$

固定这样的延拓后，

$$L_{\text{relax}} = \inf_{\mathbf{z} \in \tilde{\mathcal{Z}}} \tilde{\mathcal{E}}(\mathbf{z}) \leq \min_{\mathbf{z} \in \mathcal{Z}} \mathcal{E}(\mathbf{z}),$$

所以松弛下确界是原最小化问题的下界。若松弛问题达到该下确界，且一个松弛最优解恰好属于 $\mathcal{Z}$ ，它同时是原问题的全局最优解；若为分数解，还需取整、局部搜索或分支定界。不同目标延拓即使在全部二值点上一致，

⁴ V. Kolmogorov, R. Zabih, *What Energy Functions Can Be Minimized via Graph Cuts?* In IEEE Transactions on Pattern Analysis and Machine Intelligence, 2004, vol. 26, no. 2, pp. 147–159

也可能给出不同的松弛下界，报告结果时必须说明所用延拓。

取整得到的是一个原问题可行解及其目标上界，松弛值给出下界。二者差距

$$\mathcal{E}(\hat{\mathbf{z}}) - L_{\text{relax}}$$

是可计算的次优证书，但不等于真实误差，除非下界已经紧。逐点按 1/2 阈值取整可能破坏全局约束；随机取整的期望保证也必须说明随机性、可行性修复和适用目标。

近似算法应给出比较口径。乘法近似比适合非负且最优值不为零的目标；目标可为负或跨过零时，加法误差更合适。实例上运行很快不构成复杂度或近似保证，图结构、目标与证书必须一起报告。

14.5 图谱与离散对称性

14.5.1 图拉普拉斯把边上的差分汇总到顶点

考虑无向非负加权图，并约定非边的权重为 0。沿用前文记号， $E_+ = \{i, j\} \in E : w_{i,j} > 0\}$ ，支撑图为 $\mathcal{G}_+ = (V, E_+)$ ；本节所说的支撑连通分量均指这张图的连通分量。令 $\mathbf{W} = [w_{i,j}]$ 为对称权重矩阵， $d_i^{(w)} = \sum_j w_{i,j}$ 为顶点 i 的**加权重**（weighted degree），并令 $\mathbf{D}^{(w)} = \text{diag}(d_1^{(w)}, \dots, d_n^{(w)})$ 。它不同于第 14.1 节定义的普通度 $d_i = |N(i)|$ ；只有无权图取 $w_{i,j} = 1$ 时二者才相等⁵。**组合图拉普拉斯**（combinatorial graph Laplacian）定义为

$$\mathbf{L} = \mathbf{D}^{(w)} - \mathbf{W}. \quad (14.17)$$

⁵F. R. K. Chung, *Spectral Graph Theory*, American Mathematical Society, 1997, 1st ed.

对顶点信号 $\mathbf{f} \in \mathbb{R}^n$,

$$(\mathbf{L}\mathbf{f})_i = \sum_j w_{i,j}(f_i - f_j),$$

它比较顶点值与邻居值，并按边权汇总差异。若用前文的有向关联矩阵 $\mathbf{B}$ ，把边权放入对角矩阵 $\mathbf{W}_E$ ，则

$$\mathbf{L} = \mathbf{B}\mathbf{W}_E\mathbf{B}^\top.$$

任取边方向只改变 $\mathbf{B}$ 相应列的符号，乘积不变。

定理 14.13 图拉普拉斯的 Dirichlet 能量与零空间 对有限无向非负加权图，

$$\mathbf{f}^\top \mathbf{L}\mathbf{f} = \frac{1}{2} \sum_{i,j} w_{i,j}(f_i - f_j)^2 \geq 0. \quad (14.18)$$

因而 $\mathbf{L}$ 对称半正定。其零空间维数等于正权边构成图的连通分量数，并由各分量的指示向量张成。

证明. 展开二次型,

$$\begin{aligned}\mathbf{f}^\top \mathbf{L} \mathbf{f} &= \sum_i d_i^{(w)} f_i^2 - \sum_{i,j} w_{i,j} f_i f_j \\ &= \frac{1}{2} \sum_{i,j} w_{i,j} (f_i^2 + f_j^2 - 2f_i f_j),\end{aligned}$$

其中利用了 $w_{i,j} = w_{j,i}$ 以及 $\sum_j w_{i,j} = d_i^{(w)}$. 这就得到式 (14.18) 和半正定性.

若 $\mathbf{L} \mathbf{f} = \mathbf{0}$, 则二次型为零. 每一项非负, 所以每条正权边都满足 $f_i = f_j$. 沿正权支撑图中的路径传递可知, 同一支撑连通分量内 $\mathbf{f}$ 为常数. 反过来, 在每个支撑连通分量内取任意常数时, 每条正权边两端值相同, 而零权边不贡献 $\mathbf{L} \mathbf{f}$, 故 $\mathbf{L} \mathbf{f} = \mathbf{0}$. 各支撑连通分量的指示向量线性无关, 并生成全部这类分段常数向量, 零空间维数即为支撑连通分量数. ■

负边权会使半正定结论失效; 有向图也有多种不等价的拉普拉斯定义. 本节谱结论只针对无向非负权图.

顶点度差异很大时, 常改用**对称归一化拉普拉斯** (symmetric normalized graph Laplacian)

$$\mathbf{L}_{\text{sym}} = (\mathbf{D}^{(w)})^{-1/2} \mathbf{L} (\mathbf{D}^{(w)})^{-1/2}. \quad (14.19)$$

这里对 $d_i^{(w)} = 0$ 的孤立点约定相应逆平方根为 0, 因而孤立点对应的行列也为零. 对正度顶点, 令 $\mathbf{g} = (\mathbf{D}^{(w)})^{-1/2} \mathbf{f}$, 便有 $\mathbf{f}^\top \mathbf{L}_{\text{sym}} \mathbf{f} = \mathbf{g}^\top \mathbf{L} \mathbf{g} \geq 0$. 正度连通分量上的零特征向量不再是 $\mathbf{1}$, 而是 $(\mathbf{D}^{(w)})^{1/2} \mathbf{1}$ 在该分量上的限制.

另一常见形式是随机游走拉普拉斯 $\mathbf{L}_{\text{rw}} = (\mathbf{D}^{(w)})^{-1} \mathbf{L}$. 它在普通欧氏内积下通常不对称, 但在所有顶点度为正时与 $\mathbf{L}_{\text{sym}}$ 相似, 并在加权内积 $\langle \mathbf{x}, \mathbf{y} \rangle_{\mathbf{D}} = \mathbf{x}^\top \mathbf{D}^{(w)} \mathbf{y}$ 下自伴. 组合、对称归一化与随机游走拉普拉斯对应不同度量; 引用谱界或构造扩散前必须说明采用哪一种, 不能混用其特征向量和孤立点约定.

14.5.2 低频特征向量在强边上变化较小

由第 6 章的谱定理, $\mathbf{L}$ 有标准正交特征向量 $\mathbf{u}_1, \dots, \mathbf{u}_n$, 特征值满足

$$0 = \lambda_1 \leq \lambda_2 \leq \dots \leq \lambda_n.$$

若正权支撑图 $\mathcal{G}_+$ 连通, $\mathbf{u}_1 = \mathbf{1}/\sqrt{n}$, 且 $\lambda_2 > 0$. Rayleigh 商

$$\frac{\mathbf{f}^\top \mathbf{L} \mathbf{f}}{\mathbf{f}^\top \mathbf{f}}$$

衡量单位能量信号沿边变化多少。排除常量方向后使该商最小的向量是 $\mathbf{u}_2$, 最小值为 λ_2 。正权支撑图连通时, 这个第二特征向量称为费德勒向量 (Fiedler vector)。它在高权边两端倾向于取相近值, 因此可作为图上的低频坐标。

若取集合 $S \subset V$, 令 $s_i = \mathbb{I}\{i \in S\}$, 并记 $\mathbf{s} = (s_1, \dots, s_n)^\top$ 。这里与前章一致, $\mathbb{I}\{\cdot\}$ 表示条件成立时取 1、否则取 0 的指示函数。由式 (14.18) 可得

$$\mathbf{s}^\top \mathbf{L} \mathbf{s} = \sum_{\substack{i \in S \\ j \notin S}} w_{i,j} = \text{cut}(S, V \setminus S). \quad (14.20)$$

离散分割因此可以写成二次能量最小化。但若不限集合大小, 取 $S = \emptyset$ 或 $S = V$ 得到零割, 问题没有意义。下面分别推导按顶点数平衡的比率割和按加权重平衡的归一化割; 二者的离散目标相似, 松弛后的特征问题却不同。

先看**比率割** (RatioCut)。记 $\bar{S} = V \setminus S$, 并设 $a = |S| > 0$ 、 $b = |\bar{S}| > 0$, 于是 $a + b = n$ 。比率割定义为

$$\text{RatioCut}(S, \bar{S}) = \text{cut}(S, \bar{S}) \left(\frac{1}{a} + \frac{1}{b} \right). \quad (14.21)$$

分母惩罚把极少顶点单独切出的做法。为了把它写成二次型, 对分割构造两水平平衡向量

$$\mathbf{f}_i = \begin{cases} \sqrt{b/a}, & i \in S, \\ -\sqrt{a/b}, & i \in \bar{S}. \end{cases} \quad (14.22)$$

两侧的常数不是任意选择。它们恰好使

$$\mathbf{1}^\top \mathbf{f} = a\sqrt{\frac{b}{a}} - b\sqrt{\frac{a}{b}} = 0, \quad \mathbf{f}^\top \mathbf{f} = a\frac{b}{a} + b\frac{a}{b} = n.$$

同侧边的端点取值相同, 不贡献 Dirichlet 能量; 跨割边的端点差为

$$\sqrt{\frac{b}{a}} + \sqrt{\frac{a}{b}} = \frac{a+b}{\sqrt{ab}} = \frac{n}{\sqrt{ab}}.$$

因此

$$\begin{aligned} \mathbf{f}^\top \mathbf{L} \mathbf{f} &= \frac{n^2}{ab} \text{cut}(S, \bar{S}) \\ &= n \text{RatioCut}(S, \bar{S}), \end{aligned} \quad (14.23)$$

其中使用了 $1/a + 1/b = n/(ab)$ 。最小比率割由此等价于在所有形如式 (14.22) 的离散两水平向量中最小化 Rayleigh 商。

谱松弛去掉“两水平”限制，只保留平衡和尺度约束：

$$\min_{\substack{\mathbf{f} \in \mathbb{R}^n \\ \mathbf{f}^\top \mathbf{1} = 0, \quad \mathbf{f}^\top \mathbf{f} = n}} \frac{1}{n} \mathbf{f}^\top \mathbf{L} \mathbf{f}. \quad (14.24)$$

把任意可行向量展开为 $\mathbf{f} = \sum_{k=2}^n \alpha_k \mathbf{u}_k$ ，正交约束已经去掉 $\mathbf{u}_1$ 分量，于是

$$\frac{\mathbf{f}^\top \mathbf{L} \mathbf{f}}{\mathbf{f}^\top \mathbf{f}} = \frac{\sum_{k=2}^n \lambda_k \alpha_k^2}{\sum_{k=2}^n \alpha_k^2} \geq \lambda_2.$$

等号在 $\mathbf{f} = \sqrt{n} \mathbf{u}_2$ 时达到。因此费德勒向量解出的是 RatioCut 的 Rayleigh 松弛， λ_2 是离散最优值的下界；按符号或阈值把它转回两侧后，仍须用式 (14.21) 评价所得离散割。

归一化割 (Normalized Cut) 改用加权体积

$$\text{vol}(S) = \sum_{i \in S} d_i^{(w)}$$

衡量一侧规模。以下先假设所有顶点的加权重为正，并记 $p = \text{vol}(S)$ 、 $q = \text{vol}(\bar{S})$ 和 $\text{vol}(V) = p + q$ 。定义

$$\text{NCut}(S, \bar{S}) = \text{cut}(S, \bar{S}) \left(\frac{1}{p} + \frac{1}{q} \right). \quad (14.25)$$

把式 (14.22) 中的顶点数换成体积，令

$$y_i = \begin{cases} \sqrt{q/p}, & i \in S, \\ -\sqrt{p/q}, & i \in \bar{S}. \end{cases}$$

直接计算得到

$$\mathbf{y}^\top \mathbf{D}^{(w)} \mathbf{1} = 0, \quad \mathbf{y}^\top \mathbf{D}^{(w)} \mathbf{y} = \text{vol}(V),$$

并且

$$\mathbf{y}^\top \mathbf{L} \mathbf{y} = \text{vol}(V) \text{NCut}(S, \bar{S}).$$

放宽两水平限制后，Normalized Cut 对应的不是普通 Rayleigh 商，而是

$$\min_{\substack{\mathbf{y} \neq \mathbf{0} \\ \mathbf{y}^\top \mathbf{D}^{(w)} \mathbf{1} = 0}} \frac{\mathbf{y}^\top \mathbf{L} \mathbf{y}}{\mathbf{y}^\top \mathbf{D}^{(w)} \mathbf{y}}. \quad (14.26)$$

把分母固定为 $\text{vol}(V)$ ，相应拉格朗日函数可写成

$$\mathcal{J}(\mathbf{y}, \lambda, \mu) = \mathbf{y}^\top \mathbf{L} \mathbf{y} - \lambda \left(\mathbf{y}^\top \mathbf{D}^{(w)} \mathbf{y} - \text{vol}(V) \right) - \mu \mathbf{y}^\top \mathbf{D}^{(w)} \mathbf{1}.$$

对 $\mathbf{y}$ 求驻点条件得到

$$2\mathbf{L}\mathbf{y} - 2\lambda\mathbf{D}^{(w)}\mathbf{y} - \mu\mathbf{D}^{(w)}\mathbf{1} = \mathbf{0}.$$

左乘 $\mathbf{1}^\top$, 利用 $\mathbf{1}^\top\mathbf{L} = \mathbf{0}^\top$ 和 $\mathbf{y}^\top\mathbf{D}^{(w)}\mathbf{1} = 0$, 得到 $-\mu\text{vol}(V) = 0$, 故 $\mu = 0$. 驻点条件于是化为广义特征问题

$$\mathbf{L}\mathbf{y} = \lambda\mathbf{D}^{(w)}\mathbf{y}, \quad \mathbf{y}^\top\mathbf{D}^{(w)}\mathbf{1} = 0. \quad (14.27)$$

等价地, 令 $\mathbf{x} = (\mathbf{D}^{(w)})^{1/2}\mathbf{y}$, 式 (14.26) 变为

$$\min_{\substack{\mathbf{x} \neq \mathbf{0} \\ \mathbf{x}^\top(\mathbf{D}^{(w)})^{1/2}\mathbf{1} = 0}} \frac{\mathbf{x}^\top\mathbf{L}_{\text{sym}}\mathbf{x}}{\mathbf{x}^\top\mathbf{x}}.$$

所以应取 $\mathbf{L}_{\text{sym}}$ 的第二特征向量, 再变换回 $\mathbf{y}$; 它一般不是组合拉普拉斯 $\mathbf{L}$ 的费德勒向量。当度矩阵为标量倍单位阵, 也就是正度图为正则图时, 两类特征方向必然重合; 对一般不规则图则不能作此假定。若有孤立顶点, 体积可能为零, 必须先单独处理这些顶点或明确采用的零度约定, 不能直接除以 p 或 q 。

四顶点路径给出一个可复算的数值例。令

$$1 - 2 - 3 - 4$$

的三条边权均为 1, 则

$$\mathbf{L} = \begin{bmatrix} 1 & -1 & 0 & 0 \\ -1 & 2 & -1 & 0 \\ 0 & -1 & 2 & -1 \\ 0 & 0 & -1 & 1 \end{bmatrix}, \quad \mathbf{D}^{(w)} = \text{diag}(1, 2, 2, 1).$$

取 $S = \{1, 2\}$, 只有边 $\{2, 3\}$ 跨割。此时

$$\text{RatioCut}(S, \bar{S}) = 1, \quad \mathbf{f} = (1, 1, -1, -1)^\top, \quad \frac{\mathbf{f}^\top\mathbf{L}\mathbf{f}}{\mathbf{f}^\top\mathbf{f}} = \frac{4}{4} = 1.$$

该路径的费德勒特征值和一个对应方向为

$$\lambda_2 = 2 - \sqrt{2} \approx 0.586, \quad \mathbf{u}_2 \propto (1 + \sqrt{2}, 1, -1, -1 - \sqrt{2})^\top.$$

零阈值恢复分割 $\{1, 2\} \mid \{3, 4\}$; 枚举四顶点的非平凡二分可确认其离散 RatioCut 最优值为 1, 而松弛下界为 $2 - \sqrt{2}$ 。

同一分割两侧体积均为 3，所以

$$\text{NCut}(S, \bar{S}) = \frac{2}{3}, \quad \frac{\mathbf{f}^\top \mathbf{L} \mathbf{f}}{\mathbf{f}^\top \mathbf{D}^{(w)} \mathbf{f}} = \frac{4}{6} = \frac{2}{3}.$$

广义特征问题的第二特征值和一个对应方向则为

$$\lambda_{2,\text{sym}} = \frac{1}{2}, \quad \mathbf{y}_2 \propto (1, 1/2, -1/2, -1)^\top, \quad \mathbf{L} \mathbf{y}_2 = \frac{1}{2} \mathbf{D}^{(w)} \mathbf{y}_2.$$

阈值切分仍返回中间一刀，枚举也给出离散 NCut 最优值 $2/3$ 。两个松弛在这个对称小图上得到同一分割，但特征值和特征向量不同，正好说明 RatioCut 与 Normalized Cut 不能混成同一个特征问题。

松弛向量不是离散分割本身。按符号或阈值切分会产生一个可行割，其目标值应回到原离散目标计算。谱间隙小还意味着特征向量容易受扰动旋转；重复特征值时，稳定对象是特征子空间，不是某个算法任意选出的单一基向量。

14.5.3 扩散用矩阵函数抑制高频变化

连续时间图扩散定义为

$$\frac{d\mathbf{f}(t)}{dt} = -\mathbf{L}\mathbf{f}(t), \quad \mathbf{f}(0) = \mathbf{f}_0. \quad (14.28)$$

第 6 章的矩阵指数给出

$$\mathbf{f}(t) = \exp(-t\mathbf{L})\mathbf{f}_0 = \sum_{k=1}^n e^{-t\lambda_k} \langle \mathbf{u}_k, \mathbf{f}_0 \rangle \mathbf{u}_k.$$

特征值大的模式衰减更快，零特征值对应的分量保持不变。正权支撑图连通时， $\mathbf{f}(t)$ 趋向初始信号的常量投影；支撑图不连通时，每个支撑连通分量分别趋向自己的平均。

总和保持来自 $\mathbf{1}^\top \mathbf{L} = \mathbf{0}^\top$ ：

$$\frac{d}{dt} \mathbf{1}^\top \mathbf{f}(t) = 0.$$

平方范数与 Dirichlet 能量是两个不同的量。平方范数的导数恰好是负的 Dirichlet 能量：

$$\frac{d}{dt} \frac{1}{2} \|\mathbf{f}(t)\|_2^2 = -\mathbf{f}(t)^\top \mathbf{L} \mathbf{f}(t) \leq 0.$$

Dirichlet 能量本身也下降，但对应的导数多出一个拉普拉斯：

$$\frac{d}{dt} [\mathbf{f}(t)^\top \mathbf{L} \mathbf{f}(t)] = -2\mathbf{f}(t)^\top \mathbf{L}^2 \mathbf{f}(t) = -2\|\mathbf{L} \mathbf{f}(t)\|_2^2 \leq 0.$$

第一个等式说明非平滑分量消耗平方范数，第二个等式直接说明边上平方

差总量不会增加。扩散因此削弱顶点间差异，但不表示它保留任务所需的类别边界。扩散时间过长会把同一正权支撑连通分量内所有差异抹平。

14.5.4 离散 Dirichlet 能量与连续几何的对应有条件

式 (14.18) 是第 7 章连续 Dirichlet 能量

$$\int_{\mathcal{M}} \|\text{grad } f\|_g^2 dV_g$$

的离散对应：连续梯度衡量无穷小方向的变化，图边差分只比较被连接的样本对。两者形式相似，却不能只靠形式宣布收敛。

若图来自点云，邻域半径决定哪些局部方向被采样，核权重决定不同距离的贡献，归一化决定是否保留采样密度，边界又会改变极限条件。邻域过大可能跨越弯曲流形的不同折，过小则使图断连。样本密度不均时，未校正的图拉普拉斯可能逼近带密度漂移的算子，而不是纯粹由 Riemann 体积定义的 Laplace–Beltrami 算子。

因此，图谱只相对于已经选定的图和权重给出精确代数结论。它是否近似某个连续空间，需要额外的采样、尺度与归一化条件；它是否保留预测语义，又需要任务证据。

14.5.5 顶点重编号要求表示按置换同步变化

顶点名称只是坐标标签。同一图经置换矩阵 $\mathbf{P}$ 重编号后，

$$\mathbf{W}' = \mathbf{P}\mathbf{W}\mathbf{P}^\top, \quad \mathbf{D}^{(w)'} = \mathbf{P}\mathbf{D}^{(w)}\mathbf{P}^\top, \quad \mathbf{L}' = \mathbf{P}\mathbf{L}\mathbf{P}^\top.$$

若顶点信号也重编号为 $\mathbf{f}' = \mathbf{P}\mathbf{f}$ ，则

$$\mathbf{L}'\mathbf{f}' = \mathbf{P}\mathbf{L}\mathbf{f}.$$

图拉普拉斯作用因此对顶点置换等变：输入顶点怎样重排，输出按同样方式重排。

更一般地，图滤波器若为多项式

$$h(\mathbf{L}) = \sum_{k=0}^K a_k \mathbf{L}^k, \quad (14.29)$$

则

$$h(\mathbf{L}')\mathbf{f}' = \sum_{k=0}^K a_k (\mathbf{P}\mathbf{L}\mathbf{P}^\top)^k \mathbf{P}\mathbf{f} = \mathbf{P}h(\mathbf{L})\mathbf{f},$$

因为 $\mathbf{P}^\top\mathbf{P} = \mathbf{I}$ 。若再对顶点输出作求和等对称汇总，可以得到置换不变的图级表示。等变性只保证结果不依赖任意编号，不保证不同非同构图一定

得到不同表示。

若存在置换矩阵 $\mathbf{P}$ 使 $\mathbf{A}' = \mathbf{PAP}^T$ ，两张图称为 **同构** (isomorphic)。同构图在忽略顶点名称后具有相同连接结构。比较两个给定矩阵是否仅差重编号，不能使用一般特征分解替代：同谱图可能不同构，重复特征值下特征向量基也不唯一。

14.5.6 多重集合细化刻画局部组合信息

邻居没有天然顺序，所以一个顶点的局部结构应通过邻居标记的 **多重集合** (multiset) 表示。多重集合既记录元素种类，也记录每种元素出现次数； $\{a, a, b\}$ 与 $\{a, b\}$ 不同，但不区分排列次序。

一维 Weisfeiler-Leman 细化 (1-dimensional Weisfeiler-Leman refinement, 1-WL) 从初始标记 $c_i^{(0)}$ 出发，反复令

$$c_i^{(t+1)} = \text{HASH} \left(c_i^{(t)}, \left\{ \left\{ c_j^{(t)} : j \in N(i) \right\} \right\} \right), \quad (14.30)$$

其中 HASH 对不同输入对给出不同新标记。每轮都把顶点自身旧标记与邻居标记多重集合，因此同构重编号只会同步重排标记，不改变各标记的出现次数。

这个过程会在有限步后稳定。令 $\mathcal{P}^{(t)}$ 表示按 $c_i^{(t)}$ 相等关系得到的顶点分区。由于更新输入包含顶点自身旧标记，旧标记不同的两个顶点下一轮仍不可能获得相同标记，所以 $\mathcal{P}^{(t+1)}$ 只能细分 $\mathcal{P}^{(t)}$ ，不能合并其中的块。若分区尚未稳定，块数至少增加 1；而 n 个顶点至多分成 n 个非空块。因此从任意初始分区出发，严格细分至多发生 $n - 1$ 次。某轮分区不再改变后，下一轮每个块中的顶点仍有相同的自身标记和邻居标记计数，后续分区也保持不变。这里的“稳定”指等价类不再细分，哈希实现仍可为这些类换用新的符号名称。

细化稳定不表示已经解决图同构。若所有顶点初始同标记，六顶点环 C_6 与两个互不相连的三角形都让每个顶点始终看到两个同标记邻居；1-WL 无法区分二者，尽管一张图连通、另一张不连通。加入唯一顶点标识会人为破坏所需的重编号对称性，也不能作为无条件补救。

1-WL 提供的是局部组合表达的参照。使用共享顶点更新和对称邻域聚合的具体图网络能否达到、低于或超过该区分能力，要在模型正文中根据聚合函数、初始特征和读出方式证明。本章只建立多重集合、置换作用和细化过程，不把结构等变性升级成学习能力或泛化保证。

14.6 本章小结

图把有限变量间的直接关系从候选集合中单独提取出来。顶点和边规定关系骨架，有向、无向、加权、二部与超图分别保留不同类型的信息；邻接矩阵把邻域汇总写成线性映射，但矩阵位置依赖顶点编号。路径、环、连通分量、树与 DAG 描述局部边怎样组成整体结构，仍不自动附带概率、因果或代价语义。

结构能够改变计算组织。分隔集把图切成通过小接口相连的部分，消元则揭示中间函数会在哪些邻居间产生新联系。贯穿例中，先处理顶点 1,4 只需宽度 2，先处理顶点 2 却会补出边 {1,4} 并产生四顶点团；树分解与树宽把这种差异变成局部袋大小。树上子树的 Helly 性质进一步保证每个团都完整落入某个袋，从而使三角形等局部团给出严格的树宽下界。小树宽使精确动态规划的指数依赖局部宽度，而不是全部变量数，但寻找好分解和处理大取值域仍有成本。

结构之外还需要代数。分配律使局部汇总可以移出无关因子，半环则统一总权重、最大权重、最小成本与可达性计算。同一消元结构换用和积、最大积或最小加法会回答不同问题；求和与最大化混用时不能任意交换次序，因为这会改变哪些选择能够依赖尚未汇总的变量。

图算法的精确性各有条件。带起点与不可达边界的 Bellman 式在 DAG 上可按拓扑序递推；一般有环图需要反复松弛，并单独处理目标相关负环。非负边长支持 Dijkstra 的贪心确定，割性质支持最小生成树，残量网络把最大流与最小割连接起来，二部结构把匹配转成整数流。树宽小支持局部动态规划；二值成对能量只有满足次模不等式时，才可分解成非负割边和一元终端边，由一次最小割精确求解。一般离散目标仍需松弛、取整或搜索，并用原目标值与上下界评价结果。

图拉普拉斯从另一侧分析同一关系结构。它的二次型是边上平方差之和，零空间记录正权支撑图的连通分量，低特征值方向描述沿强边缓慢变化的信号。RatioCut 的松弛使用组合拉普拉斯的费德勒向量，Normalized Cut 则使用度加权广义特征问题，二者不能混用。矩阵指数按谱衰减高频差异；这个离散能量能否近似第 7 章的连续 Dirichlet 能量，取决于图构造、权重、采样密度、尺度与边界。顶点重编号下，拉普拉斯和多项式滤波按置换等变；1-WL 进一步用邻居标记多重集刻画局部组合信息，但仍可能无法区分某些非同构图。

由此，章首问题可以分成两层回答：连接和分解决定哪些局部计算能够复用以及中间对象多大，半环、容量、代价或顶点信号则决定计算结果的含义。第 15 章将把谱坐标用于有顺序的信号，比较规则序列频率与图频率，并把线性递推展开成随时间组织的状态核。

第五部分

动力系统、控制与决策

Dynamical Systems, Control and Decision

信号分析

第 14 章刚把局部关系写成图，并用图拉普拉斯谱描述节点信号的变化模式。更早的线性代数把矩阵理解为线性映射，矩阵分析又说明了怎样用谱坐标观察算子。当输入带有时间、空间位置等顺序时，还会出现一类额外结构：同一个局部作用可以沿位置重复使用。直接把这种作用写成一般矩阵当然可行，但那会隐藏重复的系数，也无法立即看出边界、频率和采样怎样改变结果。

本章以两个有限序列

$$\mathbf{x} = (1, 2, 1), \quad \mathbf{h} = (1, -1) \quad (15.1)$$

作为贯穿例子。我们先从平移不变的线性滤波推出卷积，再把序列系数写成多项式；复指数提供另一组坐标，使循环卷积化为逐点乘法。快速傅里叶变换、Toom-Cook 和 Winograd 类算法都利用“先改变表示、再做较少乘法、最后恢复结果”的思路，但它们使用的分解并不相同。采样部分说明什么时候这种表示仍保留原信号，图信号和状态核则把规则序列上的结论分别推广到不规则关系和递推系统。

15.1 离散信号与线性滤波

15.1.1 信号是带索引的数值对象

离散时间信号（discrete-time signal）是从整数索引到实数或复数的函数，

$$x : \mathbb{Z} \rightarrow \mathbb{C}, \quad t \mapsto x[t].$$

索引 t 可以表示时间，也可以表示一维空间位置。信号的含义来自索引顺序，而不只是一组数值：交换 $x[0]$ 与 $x[1]$ 通常会改变局部变化和滤波输出。若只有有限多个位置非零，就称信号具有有限支撑。式 (15.1) 中的 $\mathbf{x}$ 表示 $x[0] = 1, x[1] = 2, x[2] = 1$ ，其余位置取零； $\mathbf{h}$ 也作同样的零延拓。

对整数 r , 定义平移算子

$$(T_r x)[t] = x[t - r].$$

$r > 0$ 时, 原来位于 t 的值移动到 $t + r$ 。这个符号约定很重要, 因为另一种常见约定 $x[t + r]$ 会把平移方向反过来。单位脉冲

$$\delta[t] = \begin{cases} 1, & t = 0, \\ 0, & t \neq 0 \end{cases}$$

满足 $T_r \delta[t] = \delta[t - r]$ 。任意有限支撑信号都可分解为平移脉冲之和:

$$x[t] = \sum_{r \in \mathbb{Z}} x[r] \delta[t - r]. \quad (15.2)$$

对每个固定 t , 只有 $r = t$ 的一项非零。这个简单分解将把一般输入的响应归结为系统对单个脉冲的响应。

15.1.2 线性与平移不变共同推出卷积

一个离散系统 $\mathcal{H}$ 把输入信号 x 映射为输出信号 $y = \mathcal{H}x$ 。若对任意标量 a, b 及输入 x, z 都有

$$\mathcal{H}(ax + bz) = a\mathcal{H}x + b\mathcal{H}z,$$

就称系统为线性的。若

$$\mathcal{H}(T_r x) = T_r(\mathcal{H}x) \quad \text{对每个 } r \in \mathbb{Z} \text{ 成立,}$$

就称系统具有**平移不变性** (shift invariance)。这表示输入整体移动后, 输出只作同样移动, 系统在不同位置使用同一规则。

令 $h = \mathcal{H}\delta$, 称 h 为系统的**脉冲响应** (impulse response)。若 x 具有有限支撑, 式 (15.2) 是有限和, 线性性足以把 $\mathcal{H}$ 移入求和。对无穷序列, 记

$$\ell_1(\mathbb{Z}) = \left\{ x : \mathbb{Z} \rightarrow \mathbb{C} \left| \sum_{t \in \mathbb{Z}} |x[t]| < \infty \right. \right\}, \quad \|x\|_1 = \sum_{t \in \mathbb{Z}} |x[t]|.$$

也就是说, $\ell_1(\mathbb{Z})$ 由绝对可和序列组成。对一般的 $x \in \ell_1(\mathbb{Z})$, 还需假设 $\mathcal{H} : \ell_1(\mathbb{Z}) \rightarrow \ell_1(\mathbb{Z})$ 是有界线性且平移不变的算子; 这里有界表示存在与 x 无关的常数 C , 使

$$\|\mathcal{H}x\|_1 \leq C\|x\|_1.$$

令

$$x^{(N)} = \sum_{|r| \leq N} x[r] T_r \delta,$$

则 $x^{(N)} \rightarrow x$ 在 ℓ_1 范数下成立；有界性蕴含连续性，因而 $\mathcal{H}x^{(N)} \rightarrow \mathcal{H}x$ 。同时 $h = \mathcal{H}\delta \in \ell_1(\mathbb{Z})$ ，而且

$$\sum_{t \in \mathbb{Z}} \sum_{r \in \mathbb{Z}} |x[r]h[t-r]| = \|x\|_1 \|h\|_1 < \infty,$$

所以下面的无穷和绝对收敛。于是，有限支撑情形直接由线性性得到、 ℓ_1 情形通过上述极限得到

$$\begin{aligned} (\mathcal{H}x)[t] &= \mathcal{H}\left(\sum_{r \in \mathbb{Z}} x[r]T_r\delta\right)[t] \\ &= \sum_{r \in \mathbb{Z}} x[r](T_r h)[t] = \sum_{r \in \mathbb{Z}} x[r]h[t-r]. \end{aligned} \quad (15.3)$$

式 (15.3) 定义 **离散卷积** (discrete convolution)，记为

$$(x * h)[t] = \sum_{r \in \mathbb{Z}} x[r]h[t-r]. \quad (15.4)$$

核索引 $t-r$ 随 r 增加而反向读取，这个翻转是数学卷积定义的一部分。卷积满足交换律；令 $s = t-r$ 便有

$$\sum_r x[r]h[t-r] = \sum_s h[s]x[t-s] = (h * x)[t].$$

在绝对可和等允许交换求和次序的条件下，它还满足结合律和分配律。

15.1.3 相关与卷积只差一个方向，却回答不同问题

互相关 (cross-correlation) 常写为

$$(x \star h)[t] = \sum_{r \in \mathbb{Z}} x[t+r]\overline{h[r]}. \quad (15.5)$$

它把 h 按原方向滑过 x ，并在复数情形取共轭；上划线表示保持实部不变、把虚部符号反转。若定义 $\tilde{h}[r] = \overline{h[-r]}$ ，则

$$(x \star h)[t] = (x * \tilde{h})[t].$$

因此相关可以用卷积实现，但二者的核含义不同。信号处理中，相关常用于比较一个模板与不同位置的局部片段；许多神经网络库把不翻转核的相关运算称为“卷积”。只要训练和推理始终采用同一约定，参数可以适应该方向；在手算、复用滤波器或推导伴随算子时，仍必须明确是否翻转以及是否取共轭。

15.1.4 线性卷积与循环卷积采用不同边界

设 x 的支撑为 $0, \dots, m-1$, h 的支撑为 $0, \dots, r-1$ 。零延拓下的线性卷积只可能在 $0, \dots, m+r-2$ 非零, 因此完整输出长度为 $m+r-1$ 。对贯穿例,

$$\begin{aligned}(x * h)[0] &= 1, \\(x * h)[1] &= 2 - 1 = 1, \\(x * h)[2] &= 1 - 2 = -1, \\(x * h)[3] &= -1.\end{aligned}$$

所以

$$\mathbf{x} * \mathbf{h} = (1, 1, -1, -1). \quad (15.6)$$

核 $(1, -1)$ 在这里计算当前值减去前一个值; 开头和末尾的结果还包含零延拓带来的边界跳变。

若信号被视为长度 N 的周期序列, 索引应按模 N 回绕。长度 N 的 **循环卷积** (circular convolution) 定义为

$$(x *_N h)[t] = \sum_{r=0}^{N-1} x[r]h[(t-r) \bmod N], \quad t = 0, \dots, N-1. \quad (15.7)$$

把例中的 $\mathbf{h}$ 补成 $(1, -1, 0)$ 并取 $N = 3$, 可得

$$\mathbf{x} *_3 \mathbf{h} = (0, 1, -1).$$

它等于把式 (15.6) 中索引相差 3 的项相加: 首项 1 与末项 -1 叠在一起。循环边界不是零边界的近似, 而是另一个线性算子。

固定有限长度后, 线性卷积可写成 Toeplitz 矩阵乘法, 循环卷积可写成循环矩阵乘法。例如

$$\begin{bmatrix} 1 & 0 & 0 \\ -1 & 1 & 0 \\ 0 & -1 & 1 \\ 0 & 0 & -1 \end{bmatrix} \begin{bmatrix} 1 \\ 2 \\ 1 \end{bmatrix} = \begin{bmatrix} 1 \\ 1 \\ -1 \\ -1 \end{bmatrix}.$$

矩阵的重复对角线来自参数共享。裁剪为“valid”输出、补零后保持输入长度, 或使用反射、复制等边界, 都会改变矩阵的首尾行。平移不变性在无限网格或循环群上最为精确; 有限区间上的边界处理通常会破坏全局平移不变性。

“valid”并不是另一种卷积定义, 而是只保留核完全落在已知输入区间内的输出。按本章 $h[0], \dots, h[r-1]$ 的因果索引约定, 当 $m \geq r$ 时, 这些输出对应 $t = r-1, \dots, m-1$, 共 $m-r+1$ 项; 若 $m < r$, 则没有这样的

输出。补零得到的首尾输出仍有定义，但它们使用了人为指定的区间外数值。因而比较两个实现时，除了核系数，还要同时核对延拓方式、保留的输出索引和核的方向。

15.2 多项式乘法、求值与余数

15.2.1 卷积系数就是多项式乘积系数

有限序列可以用形式多项式编码。对

$$\mathbf{x} = (x_0, \dots, x_{m-1}), \quad \mathbf{h} = (h_0, \dots, h_{r-1}),$$

定义

$$X(z) = \sum_{i=0}^{m-1} x_i z^i, \quad H(z) = \sum_{j=0}^{r-1} h_j z^j.$$

变量 z 在这里首先是记录索引的形式符号。乘积为

$$\begin{aligned} X(z)H(z) &= \sum_{i=0}^{m-1} \sum_{j=0}^{r-1} x_i h_j z^{i+j} \\ &= \sum_{t=0}^{m+r-2} \left(\sum_{i+j=t} x_i h_j \right) z^t. \end{aligned} \quad (15.8)$$

括号中的系数正是 $(x * h)[t]$ 。卷积的交换律和结合律也可分别从多项式乘法的交换律和结合律得到。

贯穿例对应

$$X(z) = 1 + 2z + z^2, \quad H(z) = 1 - z,$$

因而

$$P(z) = X(z)H(z) = 1 + z - z^2 - z^3. \quad (15.9)$$

其四个系数与式 (15.6) 完全一致。这种对应没有减少计算，只是把“哪些下标相加”改写成“哪些幂次相乘”。真正的计算收益来自下一步：多项式除了系数表示，还可以用函数值或余数表示。

15.2.2 求值与插值是同一多项式的另一组坐标

次数小于 L 的多项式空间维数为 L 。选取 L 个两两不同的数 $a_0, \dots, a_{L-1}$ ，求值映射

$$E(P) = (P(a_0), \dots, P(a_{L-1}))$$

是一个线性映射。若 $E(P) = \mathbf{0}$ ，则 P 有 L 个不同根；次数小于 L 的非零多项式至多有 $L-1$ 个根，所以只能有 $P = 0$ 。求值映射是同维有限空间之间

的单射，因而可逆。其逆就是**多项式插值** (polynomial interpolation)。

具体地，Lagrange 基多项式

$$\ell_j(z) = \prod_{\substack{0 \leq k < L \\ k \neq j}} \frac{z - a_k}{a_j - a_k}$$

满足 $\ell_j(a_k) = \delta_{j,k}$ 。因此

$$P(z) = \sum_{j=0}^{L-1} P(a_j) \ell_j(z), \quad \deg P < L. \quad (15.10)$$

若要计算 $P = XH$ ，可以先分别求 $X(a_j)$ 与 $H(a_j)$ ，再用 $P(a_j) = X(a_j)H(a_j)$ 逐点相乘，最后插值。逐点乘法数是 L ，代价被转移到求值与插值中的线性组合。选点、问题规模和数值精度决定这种交换是否值得。

15.2.3 带余除法把高次信息压到指定模中

求值是余数的一种特殊情形。为建立更一般的表示，先考虑多项式除法。

定理 15.1 多项式带余除法 设 F 为一个域， $A(z), M(z) \in F[z]$ 且 $M \neq 0$ 。存在唯一的多项式 $Q(z), R(z)$ 使

$$A(z) = Q(z)M(z) + R(z), \quad \deg R < \deg M.$$

证明. 若 $\deg A < \deg M$ ，取 $Q = 0, R = A$ 即可。否则设 A 与 M 的最高次项分别为 $a_p z^p$ 与 $m_q z^q$ ，其中 $p \geq q$ 。因为 F 是域， m_q 可逆；从 A 中减去 $(a_p/m_q)z^{p-q}M$ 便消去最高次项。重复此过程，次数严格下降，有限步后得到次数小于 $\deg M$ 的余数。

若另有 $A = Q'M + R'$ 且 $\deg R', \deg R < \deg M$ ，则 $(Q - Q')M = R' - R$ 。左侧若非零，次数至少为 $\deg M$ ；右侧若非零，次数小于 $\deg M$ ，矛盾。因此 $Q = Q'$ 且 $R = R'$ 。 ■

带余除法还给出后文重构所需的互素判据。对非零多项式 A, B 反复作

$$A = Q_0 B + R_1, \quad B = Q_1 R_1 + R_2, \quad \dots$$

每个非零余数的次数都严格下降，所以过程有限步终止；最后一个非零余数经过首项归一化，就是 A, B 的**最大公因式** (greatest common divisor)。从最后一个等式向前回代，每个余数都能写成 A, B 的多项式线性组合。因此存在 $U, V \in F[z]$ 使

$$U(z)A(z) + V(z)B(z) = \gcd(A, B). \quad (15.11)$$

这就是多项式的 Bézout 恒等式。特别地, A, B 互素当且仅当可找到 U, V 使左侧等于 1; “互素” 在这里表示最大公因式为非常数。

例如

$$z^2 + 1 = (z + 1)(z - 1) + 2,$$

所以 $z - 1$ 与 $z^2 + 1$ 互素, 而且回代立即给出

$$1 = \frac{1}{2}(z^2 + 1) - \frac{1}{2}(z + 1)(z - 1).$$

后文构造中国剩余重构系数时, 使用的正是这一步, 而不是假设逆元凭空存在。

余数记为 $A \bmod M$, 并把相差 M 倍数的多项式视为同一个 **剩余类** (residue class)。当 $M(z) = z - a$ 时, 带余除法给出

$$A(z) = Q(z)(z - a) + A(a),$$

所以关于一次多项式 $z - a$ 的余数就是点值 $A(a)$ 。

模多项式还编码边界。因为在模 $z^N - 1$ 的剩余类中有 $z^N = 1$, z^{N+s} 与 z^s 的系数会合并。于是

$$(X(z)H(z)) \bmod (z^N - 1) = \sum_{t=0}^{N-1} (x *_N h)[t]z^t. \quad (15.12)$$

线性卷积与循环卷积的差别由此变成“保留普通乘积”还是“再对 $z^N - 1$ 取模”。若 $\deg(XH) < N$, 取模不会合并任何系数, 两种卷积在补零后的前 N 项相同; 若次数达到 N , 高次项就会回绕。

15.3 复指数与频率表示

15.3.1 复指数把平移变成相位乘法

后文会同时使用复数、复向量和复矩阵。记 $i^2 = -1$; 对 $z = a + ib$, 其**复共轭** (complex conjugate) 与模长分别为

$$\bar{z} = a - ib, \quad |z| = \sqrt{z\bar{z}}.$$

当 $z \neq 0$ 时, 可写成 $z = |z|e^{i\arg z}$, 其中 $\arg z$ 是相角。互相关式 (15.5) 中的上划线也表示复共轭。对 $\mathbf{u}, \mathbf{v} \in \mathbb{C}^N$, 本章采用复内积

$$\langle \mathbf{u}, \mathbf{v} \rangle = \sum_{t=0}^{N-1} u[t]\overline{v[t]}.$$

在第二个变量上取共轭使 $\langle \mathbf{u}, \mathbf{u} \rangle = \sum_t |u[t]|^2$ 为非负实数。复矩阵 $\mathbf{A}$ 的**共轭转置** (conjugate transpose) 记为 $\mathbf{A}^* = \overline{\mathbf{A}}^\top$ ；若 $\mathbf{A}^* \mathbf{A} = \mathbf{I}$ ，则称 $\mathbf{A}$ 为酉矩阵。

时域中的平移会改动许多坐标。复指数

$$\phi_\omega[t] = e^{i\omega t}$$

却在平移后只差一个标量：

$$(T_r \phi_\omega)[t] = e^{i\omega(t-r)} = e^{-i\omega r} \phi_\omega[t].$$

因此复指数是平移算子的特征函数，频率 ω 标记不同的特征模式，系数 $e^{-i\omega r}$ 记录平移产生的相位变化。这解释了频率表示为何适合分析平移不变系统：所有平移共享同一组模式。

15.3.2 离散傅里叶变换建立有限维正交坐标

对长度 N 的序列，令

$$\omega_N = e^{-2\pi i/N}.$$

离散傅里叶变换 (discrete Fourier transform, DFT) 及逆变换定义为

$$\hat{x}[k] = \sum_{t=0}^{N-1} x[t] \omega_N^{kt}, \quad k = 0, \dots, N-1, \quad (15.13)$$

$$x[t] = \frac{1}{N} \sum_{k=0}^{N-1} \hat{x}[k] \omega_N^{-kt}, \quad t = 0, \dots, N-1. \quad (15.14)$$

正变换也就是在 N 次单位根 $1, \omega_N, \dots, \omega_N^{N-1}$ 处计算多项式 $X(z)$ 的值。它既是频率坐标，也是第 15.2 节求值表示的一种特殊选点。

逆变换来自单位根的正交关系。对整数 t, s ,

$$\sum_{k=0}^{N-1} \omega_N^{k(t-s)} = \begin{cases} N, & t \equiv s \pmod{N}, \\ 0, & t \not\equiv s \pmod{N}. \end{cases} \quad (15.15)$$

第一种情形每项都是 1。第二种情形令 $q = \omega_N^{t-s} \neq 1$ ，利用 $q^N = 1$ ，几何级数之和为 $(1 - q^N)/(1 - q) = 0$ 。把式 (15.13) 代入式 (15.14)，再交换两个有限求和，只有 $s = t$ 的项留下，从而恢复 $x[t]$ 。这也证明 DFT 没有丢失长度 N 序列的信息。

若把 DFT 矩阵记为 $\mathbf{F}$ ，其中 $F_{k,t} = \omega_N^{kt}$ ，则

$$\mathbf{F}^* \mathbf{F} = N\mathbf{I}.$$

因此 $\mathbf{F}/\sqrt{N}$ 是酉矩阵。第 6 章的谱语言在这里给出一个直接解释: $\mathbf{F}/\sqrt{N}$ 才是保持二范数的正交坐标变换。本章定义的未归一化 DFT 满足 $\|\hat{\mathbf{x}}\|_2 = \sqrt{N}\|\mathbf{x}\|_2$, 逆变换中的 $1/N$ 会补回这一尺度。

15.3.3 幅度、相位与实信号的共轭对称

每个非零复系数都可写成

$$\hat{x}[k] = |\hat{x}[k]|e^{i\arg \hat{x}[k]}.$$

模长描述该频率坐标的大小, 相角描述它相对于所选时间原点的相位。若把信号循环平移 r 个位置, DFT 变为

$$\widehat{T_r x}[k] = \omega_N^{kr} \hat{x}[k].$$

幅度不变, 相位随 k 线性改变。仅保留幅度会丢失位置信息; 两个具有相同幅度谱的信号不必具有相同波形。

若 $x[t]$ 为实数, 则

$$\begin{aligned} \overline{\hat{x}[k]} &= \sum_{t=0}^{N-1} x[t] \omega_N^{-kt} \\ &= \sum_{t=0}^{N-1} x[t] \omega_N^{(N-k)t} = \hat{x}[(N-k) \bmod N]. \end{aligned}$$

这称为**共轭对称** (conjugate symmetry)。频率 0 总是实数; N 为偶数时, $k = N/2$ 对应的 Nyquist 频率也为实数。其余频率成共轭对出现, 所以实信号的完整复频谱包含冗余, 但直接丢弃一半频率时仍要保留正确的缩放和端点约定。

15.3.4 Parseval 关系说明能量只是在坐标间重排

由 $\mathbf{F}^* \mathbf{F} = N\mathbf{I}$,

$$\|\hat{\mathbf{x}}\|_2^2 = \mathbf{x}^* \mathbf{F}^* \mathbf{F} \mathbf{x} = N\|\mathbf{x}\|_2^2.$$

于是得到离散的**Parseval 关系**

$$\sum_{t=0}^{N-1} |x[t]|^2 = \frac{1}{N} \sum_{k=0}^{N-1} |\hat{x}[k]|^2. \quad (15.16)$$

这里的 $1/N$ 来自本章把归一化全部放在逆变换中。若正逆变换各用 $1/\sqrt{N}$, 等式两侧便没有额外因子。比较不同资料中的频谱数值前, 必须先核对变换的符号与归一化约定。

15.3.5 连续周期信号需要区分收敛方式

有限维 DFT 只涉及有限求和, 不存在无穷级数的收敛问题。把同一正交展开思路推广到连续周期信号后, 才需要区分平方平均收敛与逐点收敛。对周期为 T 的平方可积连续信号 $f(t)$, 复指数 $e^{i2\pi kt/T}$ 在内积

$$\langle f, g \rangle = \frac{1}{T} \int_0^T f(t) \overline{g(t)} dt$$

下正交。其**傅里叶系数** (Fourier coefficient) 为

$$c_k = \frac{1}{T} \int_0^T f(t) e^{-i2\pi kt/T} dt.$$

形式上, 傅里叶级数写为

$$f(t) \sim \sum_{k \in \mathbb{Z}} c_k e^{i2\pi kt/T}. \quad (15.17)$$

若只假设 $f \in L^2[0, T]$, 等号应理解为平方平均意义下收敛; 逐点收敛还需要额外规则性, 并且跳跃点处通常收敛到左右极限的平均。频率展开不是无条件的逐点恒等式。在相同归一化下, 连续周期信号还满足 Parseval 关系

$$\frac{1}{T} \int_0^T |f(t)|^2 dt = \sum_{k \in \mathbb{Z}} |c_k|^2. \quad (15.18)$$

它是 L^2 中的能量恒等式, 不要求傅里叶级数在每一点都等于 f 。

一个具体边界例子是周期为 2π 的方波: 在 $0 < t < \pi$ 取 1, 在 $-\pi < t < 0$ 取 -1, 再作周期延拓。直接积分得到 $c_0 = 0$, 偶数 k 对应 $c_k = 0$, 奇数 k 对应

$$c_k = \frac{2}{\pi i k}.$$

方波在除跳跃点外的每个连续点由级数恢复, 在跳跃点则收敛到左右极限的平均 0; 与此同时, 式 (15.18) 仍在 L^2 意义下成立。这一区别说明, 平均平方误差趋于零并不能逐点排除跳跃附近的振荡。

15.4 卷积定理与快速变换

15.4.1 循环卷积在频域中逐点相乘

定理 15.2 离散循环卷积定理 设 x, h 为长度 N 的复序列, DFT 采用式 (15.13) 的约定, 则

$$\widehat{x *_N h}[k] = \hat{x}[k] \hat{h}[k], \quad k = 0, \dots, N-1.$$

证明. 从定义出发, 并把 $a = (t - r) \bmod N$ 作为新的求和索引:

$$\begin{aligned}\widehat{x * _N h}[k] &= \sum_{t=0}^{N-1} \sum_{r=0}^{N-1} x[r] h[(t - r) \bmod N] \omega_N^{kt} \\ &= \sum_{r=0}^{N-1} \sum_{a=0}^{N-1} x[r] h[a] \omega_N^{k(r+a)} \\ &= \left(\sum_{r=0}^{N-1} x[r] \omega_N^{kr} \right) \left(\sum_{a=0}^{N-1} h[a] \omega_N^{ka} \right).\end{aligned}$$

第二个等号中, t 遍历一个完整剩余类时 a 也恰好遍历 $0, \dots, N-1$; 即使 t 与 $r+a$ 相差 N 的整数倍, $\omega_N^{kN} = 1$ 也保证幂值不变。最后两项分别是 $\hat{x}[k]$ 和 $\hat{h}[k]$ 。■

因此

$$x * _N h = \mathcal{F}_N^{-1}(\mathcal{F}_N(x) \odot \mathcal{F}_N(h)). \quad (15.19)$$

循环卷积矩阵由 DFT 基对角化, 每个频率上的“特征值”就是核的 DFT 系数。这个结论同时连接了第 6 章的谱分解和本章的多项式求值: 循环矩阵、模 $z^N - 1$ 的乘法与单位根求值描述的是同一个算子。

若要得到长度 $m + r - 1$ 的线性卷积, 必须把两个序列都补零到

$$N \geq m + r - 1. \quad (15.20)$$

此时乘积次数小于 N , 模 $z^N - 1$ 不会发生系数回绕。只把两者补到 $N \geq \max(m, r)$ 不够; 它保证输入装得下, 却未保证乘积装得下。

15.4.2 FFT 利用单位根的递归结构

直接计算 N 个 DFT 系数, 每个需要 N 项求和, 运算量为 $O(N^2)$ 。**快速傅里叶变换** (fast Fourier transform, FFT) 不是另一种变换, 而是一族利用求值点结构快速计算 DFT 的算法¹。以 N 为偶数的基二 Cooley-Tukey 分解为例, 将输入的偶数项与奇数项分别组成

$$x_e[r] = x[2r], \quad x_o[r] = x[2r + 1].$$

记它们的长度 $N/2$ DFT 为 $E[k]$ 和 $O[k]$ 。因为 $\omega_N^2 = \omega_{N/2}$, 对 $0 \leq k < N/2$ 有

$$\begin{aligned}\hat{x}[k] &= E[k] + \omega_N^k O[k], \\ \hat{x}[k + N/2] &= E[k] - \omega_N^k O[k].\end{aligned} \quad (15.21)$$

¹ J. W. Cooley, J. W. Tukey, *An Algorithm for the Machine Calculation of Complex Fourier Series* In *Mathematics of Computation*, 1965, vol. 19, no. 90, pp. 297–301

第二式利用了 $\omega_N^{N/2} = -1$ 。两个较小 DFT 的同一对结果通过一次加法和一次减法产生两个频率，并没有舍弃后半频率。

当 $N = 2^q$ 时，递推

$$T(N) = 2T(N/2) + O(N)$$

给出 $T(N) = O(N \log N)$ 。其他合数长度可按不同因子分解，质数长度也有相应算法；“使用 FFT”不等于必须补到二的幂。补到更方便的长度可能降低实现常数，也可能增加无用频点和存储，需按具体规模判断。

对贯穿例补零到 $N = 4$ ：

$$\mathbf{x}_4 = (1, 2, 1, 0), \quad \mathbf{h}_4 = (1, -1, 0, 0).$$

对 $\mathbf{x}_4$ ，偶数分支 $(1, 1)$ 的二点 DFT 为 $(2, 0)$ ，奇数分支 $(2, 0)$ 的二点 DFT 为 $(2, 2)$ 。取 $\omega_4 = -i$ 并按式 (15.21) 合并，得到

$$(2 + 2, 0 - 2i, 2 - 2, 0 + 2i) = (4, -2i, 0, 2i).$$

同理， $\mathbf{h}_4$ 的偶、奇分支 DFT 分别为 $(1, 1)$ 与 $(-1, -1)$ ，蝶形合并得到 $(0, 1 + i, 2, 1 - i)$ 。这一步显示四点结果如何由两个二点变换复用，而不只是直接代入 DFT 定义。

在 $1, -i, -1, i$ 四个单位根处，

$$\hat{\mathbf{x}}_4 = (4, -2i, 0, 2i), \quad \hat{\mathbf{h}}_4 = (0, 1 + i, 2, 1 - i).$$

例如逆变换的四个分子依次为

$$4 - 2i + 2i, \quad 4 + 2 + 2, \quad 4 + 2i - 2i, \quad 4 - 2 - 2,$$

除以 4 后恢复 $(1, 2, 1, 0)$ 。这一步同时核对了频率顺序、指数符号和 $1/N$ 归一化，任何一项约定改变都要相应修改逆变换。

逐点乘积为

$$(0, 2 - 2i, 0, 2 + 2i),$$

逆 DFT 恢复 $(1, 1, -1, -1)$ 。若只用 $N = 3$ ，末项会回绕到首项，得到的便是 $(0, 1, -1)$ 而非线性卷积。

15.4.3 Toom-Cook 用一般求值点减少系数乘法

Toom-Cook 方法把多项式分块，选择足够多的求值点，逐点相乘后再插值。对本例的二次多项式 X 与一次多项式 H ，乘积次数至多为 3，可使用 $0, 1, -1, \infty$ 四个点；其中“在 ∞ 处求值”只表示读取最高次项系数，并非

把无穷大传给数值程序²。记

$$r_0 = X(0)H(0), \quad r_+ = X(1)H(1), \quad r_- = X(-1)H(-1), \quad r_\infty = x_2 h_1.$$

若 $P(z) = c_0 + c_1 z + c_2 z^2 + c_3 z^3$, 则

$$\begin{aligned} c_0 &= r_0, & c_3 &= r_\infty, \\ c_1 &= \frac{r_+ - r_-}{2} - c_3, \\ c_2 &= \frac{r_+ + r_-}{2} - c_0. \end{aligned} \quad (15.22)$$

这些式子由 $P(1)$ 与 $P(-1)$ 的和、差直接解出。

对式 (15.9),

$$(r_0, r_+, r_-, r_\infty) = (1, 0, 0, -1),$$

代入式 (15.22) 得到 $(c_0, c_1, c_2, c_3) = (1, 1, -1, -1)$ 。直接展开需要 $3 \times 2 = 6$ 个输入系数与核系数之间的乘法, 这个求值方案只需四个点值乘法, 但新增了求值、插值和常数乘除。对长多项式递归分块时才得到相应的渐近改进; 对短核, 只数核心乘法会掩盖变换和访存成本。

15.4.4 余数分解与多项式中国剩余定理

点值只保留关于一次多项式的余数。Winograd 类算法更一般地选择若干互素模多项式, 分别计算低次余数, 再重构所需乘积或滤波输出。其代数依据是下面的多项式中国剩余定理³。

定理 15.3 多项式中国剩余定理 设 F 为一个域, $m_1(z), \dots, m_s(z) \in F[z]$ 两两互素, 并令 $M(z) = \prod_{j=1}^s m_j(z)$ 。映射

$$[A]_M \mapsto ([A]_{m_1}, \dots, [A]_{m_s})$$

是环同构。换言之, 关于各 m_j 的余数唯一确定次数小于 $\deg M$ 的 $A \bmod M$ 。

证明. 若两个多项式 A, B 在每个 m_j 下余数相同, 则每个 m_j 都整除 $A - B$ 。这里需要说明两两互素如何推出乘积整除。若互素多项式 a, b 都整除 q , 写成 $q = ac$; 由 Bézout 恒等式 $ua + vb = 1$ 可得

$$c = uac + vbc = uq + vbc,$$

故 b 整除 c , 进而 ab 整除 q 。两两互素时, 任意若干因子的乘积仍与其余因子互素, 反复应用这个 Euclid 引理便得 M 整除 $A - B$ 。所以 A, B 属于同一个模 M 剩余类, 映射为单射。

² D. E. Knuth, *The Art of Computer Programming, Volume 2: Seminumerical Algorithms*, Addison-Wesley, 1997, 3rd ed.

³ S. Winograd, *Arithmetic Complexity of Computations*, Society for Industrial and Applied Mathematics, 1980

为构造任意给定余数 r_j 的原像, 令 $M_j = M/m_j$ 。由于 M_j 与 m_j 互素, Bézout 恒等式给出多项式 u_j, v_j 使

$$u_j M_j + v_j m_j = 1.$$

于是 $e_j = u_j M_j$ 关于 m_j 的余数为 1, 关于其余 m_k 的余数为 0。多项式

$$A = \sum_{j=1}^s r_j e_j$$

便具有全部指定余数。再对 M 取余即可得到唯一的次数小于 $\deg M$ 的代表元。 ■

仍用同一个乘积, 并取

$$M(z) = z^4 - 1 = (z - 1)(z + 1)(z^2 + 1).$$

这三个因子在 $\mathbb{R}[z]$ 中两两互素, 总次数为 4。分别计算 XH 的余数:

$$P(1) = 0, \quad P(-1) = 0,$$

而在模 $z^2 + 1$ 下有 $z^2 = -1$,

$$X(z) \equiv 2z, \quad H(z) \equiv 1 - z, \quad X(z)H(z) \equiv 2 + 2z.$$

设重构结果 R 的次数小于 4。前两个余数为零说明 R 可写为

$$R(z) = (z^2 - 1)(az + b).$$

再对 $z^2 + 1$ 取模, 得到 $R \equiv -2az - 2b$ 。与 $2 + 2z$ 比较可得 $a = b = -1$, 所以

$$R(z) = 1 + z - z^2 - z^3.$$

由于原乘积次数已经小于 4, 这个模 $z^4 - 1$ 的代表元就是完整乘积本身。从输入输出形状看, 这次余数计算把长度 3 与长度 2 的系数向量映射为长度 4 的完整线性卷积。若只要求中间若干项, Winograd 最小滤波会据此重新选择余数与恢复映射; 不能把这里恢复全部四项的变换直接当作任意输出块的最小算法。

示例 15.4 可复核的 Winograd $F(2, 3)$ 输出块 考虑一维“valid”互相关。长度为 4 的输入块 $\mathbf{d} = (d_0, d_1, d_2, d_3)^\top \in \mathbb{R}^4$ 与长度为 3 的核 $\mathbf{g} = (g_0, g_1, g_2)^\top \in \mathbb{R}^3$ 产生长度为 2 的输出块

$$y_0 = d_0 g_0 + d_1 g_1 + d_2 g_2, \quad y_1 = d_1 g_0 + d_2 g_1 + d_3 g_2.$$

$F(2, 3)$ 选取关于 z 、 $z-1$ 、 $z+1$ 的余数，并补上最高次系数坐标；前三项分别对应应在 $0, 1, -1$ 处的值。核侧变换直接是这些余数坐标的缩放，输入侧还要针对只恢复上述两个中间系数作固定线性组合。按本例的互相关方向，一组变换为

$$\mathbf{y} = \mathbf{A}^\top \left[(\mathbf{G}\mathbf{g}) \odot (\mathbf{B}^\top \mathbf{d}) \right], \quad (15.23)$$

其中

$$\mathbf{B}^\top = \begin{bmatrix} 1 & 0 & -1 & 0 \\ 0 & 1 & 1 & 0 \\ 0 & -1 & 1 & 0 \\ 0 & 1 & 0 & -1 \end{bmatrix},$$

$$\mathbf{G} = \begin{bmatrix} 1 & 0 & 0 \\ 1/2 & 1/2 & 1/2 \\ 1/2 & -1/2 & 1/2 \\ 0 & 0 & 1 \end{bmatrix},$$

$$\mathbf{A}^\top = \begin{bmatrix} 1 & 1 & 1 & 0 \\ 0 & 1 & -1 & -1 \end{bmatrix}.$$

因而形状依次为

$$\mathbb{R}^4 \xrightarrow{\mathbf{B}^\top} \mathbb{R}^4, \quad \mathbb{R}^3 \xrightarrow{\mathbf{G}} \mathbb{R}^4, \quad \mathbb{R}^4 \xrightarrow{\mathbf{A}^\top} \mathbb{R}^2.$$

取 $\mathbf{d} = (1, 2, 3, 4)^\top$ 、 $\mathbf{g} = (2, -1, 1)^\top$ ，可逐步核对

$$\mathbf{B}^\top \mathbf{d} = (-2, 5, 1, -2)^\top, \quad \mathbf{G}\mathbf{g} = (2, 1, 2, 1)^\top.$$

四次逐坐标乘法得到 $\mathbf{m} = (-4, 5, 2, -2)^\top$ ，再作输出变换便有

$$\mathbf{A}^\top \mathbf{m} = (3, 5)^\top.$$

直接互相关也给出 $y_0 = 2 - 2 + 3 = 3$ 与 $y_1 = 4 - 3 + 4 = 5$ 。这个小块把直接计算的六次输入-核乘法换成四次逐坐标乘法；矩阵变换中的加减和常数乘法仍须计入实现成本。

该例也揭示 FFT、Toom-Cook 与余数算法的联系和区别。FFT 在 $z^N - 1$ 的全部复单位根处求值，并利用根的规则结构快速变换；Toom-Cook 可选一般求值点并插值完整乘积；Winograd 类构造从更一般的互素余数出发，常以减少特定小块滤波所需的乘法为目标。一次因子的 CRT 与普通点值插值重合，但高次模因子会保留一个低次多项式余数，不能再把它说成单个点值。

15.4.5 算法比较必须同时核对算术、误差与边界

长度相近的两个 n 项序列直接卷积需要 $O(n^2)$ 次乘加；FFT 路线在适合的变换长度上需要 $O(N \log N)$ 次变换运算和 N 次频域乘法。Toom–Cook 通过递归分块减少组合乘法，Winograd 最小滤波则针对固定输出块减少核心乘法。渐近量级或乘法次数都不是完整的运行时间模型：加减、常数乘法、复数运算、数据变换、缓存复用和目标硬件同样重要。

数值误差也依赖表示。归一化 DFT 矩阵是酉矩阵，坐标变换本身条件良好，但有限精度的多层蝶形仍会累积舍入误差；Toom–Cook 与 Winograd 的求值、插值矩阵可能含尺度差异较大的系数，相近量相减也可能放大相对误差。整数或有限域中，若模数和变换长度允许，可以用数论变换避免浮点舍入，但还要防止模运算后的系数范围歧义。不存在脱离数据类型、规模和误差目标而普遍最优的卷积算法。

边界条件更不能由快速算法自动决定。FFT 默认循环卷积，线性卷积必须满足式 (15.20)；Toom–Cook 恢复的是所设多项式乘积，网络互相关还需翻转或重新排列核；Winograd 小块算法只恢复设计时指定的输出，步长、空洞率或边界变化后需要重新推导。不同算法可以计算同一映射，但前提是输入延拓、核方向、输出裁剪与数值精度均保持一致。

15.5 采样与信息损失

15.5.1 一个混叠例子说明丢失为何不可逆

离散序列常来自连续信号 $f(t)$ 在间隔 T_s 上的观测：

$$x[n] = f(nT_s), \quad \nu_s = \frac{1}{T_s}.$$

这里 ν_s 是采样频率。若不限制原信号允许包含的频率，采样通常不能唯一确定连续信号。令 $T_s = 1$ ，考虑

$$f_1(t) = \cos(0.8\pi t), \quad f_2(t) = \cos(1.2\pi t).$$

两者具有不同频率，但在整数样本上

$$f_2[n] = \cos(1.2\pi n) = \cos(2\pi n - 0.8\pi n) = \cos(0.8\pi n) = f_1[n].$$

只看样本，无法判断原信号来自 0.8π 还是 1.2π 。任何后续插值器都只能在多个相容连续信号中作选择，不能从相同数据恢复已经丢失的区别。

这个例子也解释了为什么“先下采样，再学习恢复”没有一般的信息保证。模型可以利用训练分布偏好猜测常见的高频细节，但若两个输入在采样后完全相同，任何确定性后续映射对它们也只能给出同一输出。恢复效

果来自额外先验或数据规律，而不是下采样本身可逆。上面的纯余弦在整条实轴上不属于 $L^2(\mathbb{R})$ ，这里只用来直观展示功率信号中的采样歧义；下面转入平方可积带限信号，给出函数空间闭合的重构结论。

15.5.2 采样会把连续频谱周期复制

设 $f \in L^2(\mathbb{R})$ 。当 $f \in L^1(\mathbb{R}) \cap L^2(\mathbb{R})$ 时，连续时间傅里叶变换先由普通积分定义为

$$F(\Omega) = \int_{-\infty}^{\infty} f(t)e^{-i\Omega t} dt.$$

Plancherel 定理把这个变换唯一延拓到 $L^2(\mathbb{R})$ ；本节的 F 均指这一 L^2 意义下的傅里叶变换。若 $F(\Omega) = 0$ 对几乎处处的 $|\Omega| > \Omega_{\max}$ 成立，就称 f 带限于 $\Omega_{\max}$ 。Paley-Wiener 带限空间就是满足该条件的 $L^2(\mathbb{R})$ 函数所组成的空间。

由 Plancherel 定理， $F \in L^2(\mathbb{R})$ 。带限条件又把其支撑限制在有限测度区间内，所以 Cauchy-Schwarz 不等式给出

$$\|F\|_1 \leq \sqrt{2\Omega_{\max}} \|F\|_2 < \infty.$$

因此逆变换积分

$$f_c(t) = \frac{1}{2\pi} \int_{-\Omega_{\max}}^{\Omega_{\max}} F(\Omega)e^{i\Omega t} d\Omega$$

定义了 f 的一个连续代表元。下面仍把这个代表元记为 f ，点值 $f(nT_s)$ 与采样都针对它定义。

令采样角频率为

$$\Omega_s = \frac{2\pi}{T_s},$$

并把区间 $I_s = [-\pi/T_s, \pi/T_s]$ 称为一个**基带** (baseband)。把频谱副本按间隔 Ω_s 相加，定义

$$P_F(\Omega) = \frac{1}{T_s} \sum_{k \in \mathbb{Z}} F(\Omega - k\Omega_s).$$

由于 F 带限，对几乎每个固定 Ω 只有有限项非零；在 I_s 上只会有限多个 F 的平移，因此 $P_F \in L^2(I_s)$ 。函数 P_F 以 Ω_s 为周期，并且它在 I_s 上的第 n 个傅里叶系数为

$$\begin{aligned} \frac{1}{\Omega_s} \int_{I_s} P_F(\Omega)e^{i\Omega nT_s} d\Omega &= \frac{1}{2\pi} \int_{\mathbb{R}} F(\Omega)e^{i\Omega nT_s} d\Omega \\ &= f(nT_s) = x[n]. \end{aligned}$$

第一步把各个平移区间拼回整条实轴，并使用 $e^{inT_s\Omega_s} = e^{i2\pi n} = 1$ ；第二步是逆傅里叶变换。由 $P_F \in L^2(I_s)$ 及傅里叶级数的 Parseval 关系，其系数序列 $\{x[n]\}_{n \in \mathbb{Z}}$ 属于 $\ell_2(\mathbb{Z})$ 。因此离散样本的频率表示可以定义为 $L^2(I_s)$ 意义

下的傅里叶级数

$$X_s(\Omega) = \sum_{n \in \mathbb{Z}} x[n] e^{-i\Omega n T_s}.$$

它与 P_F 具有相同的傅里叶系数, 故二者在 $L^2(I_s)$ 中相同, 即

$$X_s(\Omega) = \frac{1}{T_s} \sum_{k \in \mathbb{Z}} F(\Omega - k\Omega_s). \quad (15.24)$$

采样不是只截取一份频谱, 而是把原频谱按 Ω_s 周期复制并相加。

若 $\Omega_s > 2\Omega_{\max}$, 相邻副本互不重叠, 可以用理想低通滤波器取回中央副本。若 $\Omega_s < 2\Omega_{\max}$, 允许频带的相邻副本在正测度区间上重叠, 采样映射在整个 Paley-Wiener 空间上不再是单射。不同连续频率由此落到同一离散频率, 这种现象称为**混叠** (aliasing)。临界等号 $\Omega_s = 2\Omega_{\max}$ 则不同: 在当前 L^2 模型中, 相邻副本至多在端点相接, 零测端点不改变频谱的 L^2 等价类, 不能把它无条件判为混叠。

另一种常见推导把采样写成信号与 Dirac 脉冲列的乘积, 再对脉冲列作傅里叶变换; 其中的乘积、变换和等式都要在广义函数意义下解释。本章不调用这套理论, 而以上述基带傅里叶级数作为证明接口。

定理 15.5 带限信号的采样重构 若 f 属于上述 Paley-Wiener 空间, 频谱支撑包含于 $[-\Omega_{\max}, \Omega_{\max}]$, 且 $\Omega_s > 2\Omega_{\max}$, 则 f 由样本 $f(nT_s)$ 唯一确定, 并可写成

$$f(t) = \sum_{n \in \mathbb{Z}} f(nT_s) \operatorname{sinc}\left(\frac{t - nT_s}{T_s}\right), \quad \operatorname{sinc}(u) = \frac{\sin(\pi u)}{\pi u}. \quad (15.25)$$

级数在 $L^2(\mathbb{R})$ 中收敛, 并在额外的常见正则条件下逐点或一致收敛。

证明. 记 $I_s = [-\pi/T_s, \pi/T_s]$ 。条件 $\Omega_s > 2\Omega_{\max}$ 保证 F 的支撑严格包含在 I_s 内, 式 (15.24) 在该区间上只有中央副本, 即 $F = T_s X_s$ 。因此 F 在 I_s 上的傅里叶系数为 $T_s f(nT_s)$, 相应部分和

$$F_N(\Omega) = T_s \sum_{n=-N}^N f(nT_s) e^{-i\Omega n T_s}$$

在 $L^2(I_s)$ 中收敛到 F 。把 F_N 在 I_s 外取为零, 再作逆傅里叶变换。有限求和可以直接移到积分外, 得到

$$\begin{aligned} f_N(t) &= \sum_{n=-N}^N f(nT_s) \frac{T_s}{2\pi} \int_{-\pi/T_s}^{\pi/T_s} e^{i\Omega(t-nT_s)} d\Omega \\ &= \sum_{n=-N}^N f(nT_s) \operatorname{sinc}\left(\frac{t - nT_s}{T_s}\right). \end{aligned}$$

第二个等号只需计算对称区间上的指数积分；当 $t = nT_s$ 时，按连续延拓把 $\text{sinc}(0)$ 取为 1。傅里叶变换在 L^2 中的等距性质说明 $F_N \rightarrow F$ 蕴含 $f_N \rightarrow f$ ，于是令 $N \rightarrow \infty$ 便得到式 (15.25)。

若两条满足条件的信号具有同一样本，则它们频谱在 I_s 上的全部傅里叶系数相同。傅里叶级数在 $L^2(I_s)$ 中的唯一性说明两频谱几乎处处相同，逆变换后两信号也在 $L^2(\mathbb{R})$ 中相同。这同时给出唯一性。 ■

定理采用严格不等号，以便让频谱支撑严格落在基带内部并留出低通余量。在当前 Paley-Wiener L^2 模型中，同一证明可按几乎处处意义延伸到 $\Omega_s = 2\Omega_{\max}$ ，因为端点相接不影响 L^2 等价类。若把信号类扩大到允许谱线的广义函数或功率信号，临界点才需要另行处理：例如 $\sin(\Omega_{\max}t)$ 在 $T_s = \pi/\Omega_{\max}$ 时的全部样本均为零，但它不属于 $L^2(\mathbb{R})$ 。两种结论针对的信号类不同。

实际观测只有有限时长，理想 sinc 具有无限支撑，噪声与非带限成分也不会因定理而消失。因此该定理给出理想信号类中的无混叠重构条件，不是有限数据上的无误差保证。

15.5.3 离散时间傅里叶变换与频率响应

采样得到的是双向无穷序列，不能直接把长度 N 的 DFT 当作它的频率表示。对 $x \in \ell_1(\mathbb{Z})$ ，定义**离散时间傅里叶变换**（discrete-time Fourier transform, DTFT）

$$X(e^{i\omega}) = \sum_{n \in \mathbb{Z}} x[n]e^{-i\omega n}, \quad \omega \in \mathbb{R}. \quad (15.26)$$

绝对可和保证级数收敛，并使 $X(e^{i\omega})$ 成为连续的 2π 周期函数。对 $x \in \ell_2(\mathbb{Z})$ ，同一表达按傅里叶级数在 $L^2([-\pi, \pi])$ 中解释，等式只需几乎处处成立。DFT 把 N 个数映到 N 个离散频率坐标，并带有长度 N 的周期边界；DTFT 则把无穷序列映到连续频率变量上的周期函数。

设滤波核 h 具有有限支撑或属于 $\ell_1(\mathbb{Z})$ 。虽然复指数 $x[t] = e^{i\omega t}$ 本身不属于 ℓ_1 ， h 的绝对可和性仍保证下面的卷积和逐点绝对收敛：

$$\begin{aligned} (x * h)[t] &= \sum_r h[r]e^{i\omega(t-r)} \\ &= e^{i\omega t} \sum_r h[r]e^{-i\omega r}. \end{aligned}$$

输出仍是同一频率，只乘以

$$H(e^{i\omega}) = \sum_r h[r]e^{-i\omega r}, \quad (15.27)$$

即滤波器的**频率响应** (frequency response), 也就是 h 的 DTFT。其模长决定该模式被放大或削弱多少, 相位决定时间位置怎样变化。

例中 $h = (1, -1)$ 的响应为

$$H(e^{i\omega}) = 1 - e^{-i\omega}, \quad |H(e^{i\omega})| = 2|\sin(\omega/2)|.$$

常量模式 $\omega = 0$ 被完全消去, 接近零频的缓慢变化也被削弱, 高频变化则较强。因此该核可作一阶差分, 但边界延拓仍会决定有限序列首尾出现什么响应。

15.5.4 下采样前的滤波决定哪些频率被保留

对离散信号每隔 M 个位置保留一项,

$$y[n] = x[Mn],$$

称为 M 倍**下采样** (downsampling)。沿用式 (15.26) 的 DTFT 约定,

$$Y(e^{i\omega}) = \frac{1}{M} \sum_{\ell=0}^{M-1} X(e^{i(\omega+2\pi\ell)/M}). \quad (15.28)$$

要验证这个式子, 把右侧的 X 按定义展开并交换有限和与级数:

$$\begin{aligned} \frac{1}{M} \sum_{\ell=0}^{M-1} X(e^{i(\omega+2\pi\ell)/M}) &= \sum_{r \in \mathbb{Z}} x[r] e^{-ir\omega/M} \left(\frac{1}{M} \sum_{\ell=0}^{M-1} e^{-2\pi i \ell r/M} \right) \\ &= \sum_{n \in \mathbb{Z}} x[Mn] e^{-i\omega n}. \end{aligned}$$

括号中的单位根之和只在 r 是 M 的倍数时等于 1, 其余情形为 0, 所以最后一行正是 $y[n] = x[Mn]$ 的频谱。对于绝对可和序列, 上述交换直接成立; 更一般的能量有限序列需在 L^2 意义下解释。

输入模式 $e^{i\omega_0 n}$ 经下采样后变成 $e^{iM\omega_0 n}$, 所以输入频率映到 $M\omega_0 \bmod 2\pi$ 。换言之, 原频谱沿输出频率轴扩展 M 倍, 再由 2π 周期副本相加; 超出主值区间的部分会回绕并可能混叠。要避免不同项重叠, 应在下采样前用低通滤波器把频率限制到 $|\omega| < \pi/M$ 附近; 这一步称为 **抗混叠滤波** (anti-aliasing filtering)。有限长度滤波器不能实现理想砖墙频响, 工程设计需要在过渡带、延迟、计算量和阻带衰减之间取舍。

平均池化可以看作低通滤波后下采样。长度 M 的均值核

$$h[n] = \begin{cases} 1/M, & 0 \leq n < M, \\ 0, & \text{其他} \end{cases}$$

具有频率响应

$$H(e^{j\omega}) = \frac{1}{M} e^{-j\omega(M-1)/2} \frac{\sin(M\omega/2)}{\sin(\omega/2)}. \quad (15.29)$$

当 $\omega \in 2\pi\mathbb{Z}$ 使正弦商呈 $0/0$ 形式时, 按原有限和的连续延拓取 $H(e^{j\omega}) = 1$ 。它削弱部分高频, 却不是理想低通, 旁瓣仍可能在下采样后产生混叠。最大池化是非线性运算, 不能用一个固定频率响应完整描述; 它同样会合并多个位置, 因而通常不可逆。

可以在同一输入上比较三种处理。令

$$x[n] = \cos(0.2\pi n) + \cos(0.8\pi n),$$

并作二倍下采样。直接抽取给出

$$x[2m] = 2 \cos(0.4\pi m),$$

因为 0.8π 分量抽取后折叠到与 0.2π 分量相同的离散频率。若先用理想低通完全删除 0.8π 分量, 输出则为 $\cos(0.4\pi m)$ 。若只用两点均值 $h = (1/2, 1/2)$, 由

$$\frac{\cos(\omega n) + \cos(\omega(n-1))}{2} = \cos(\omega/2) \cos(\omega n - \omega/2)$$

可知两个分量在抽取后仍会相加, 只是分别乘上 $\cos(0.1\pi)$ 与 $\cos(0.4\pi)$ 并产生相位偏移。具体输出为

$$\cos(0.1\pi) \cos(0.4\pi m - 0.1\pi) + \cos(0.4\pi) \cos(1.6\pi m - 0.4\pi).$$

第二项仍会折回较低离散频率。局部平均降低了高频项的幅度, 却没有把它消除; “先平滑”与“满足无混叠带限条件”不是同一个保证。

滤波、裁剪、量化、池化和降维都可能丢失信息, 判断能否恢复必须说明限制在哪个信号类上。若某个滤波器在一段频率上响应为零, 该频段分量进入零空间; 若下采样发生混叠, 不同输入落到同一输出。第 5 章的零空间和第 6 章的小奇异值语言因此仍适用: 精确零响应意味着不可识别, 接近零的响应意味着反演对噪声敏感。

15.6 图信号与状态核

15.6.1 图傅里叶变换用拉普拉斯特征向量定义变化模式

规则序列有统一的“向前一步”, 平移算子因而自然; 不规则关系上却没有唯一的全局平移。设无向加权图 $\mathcal{G} = (V, E)$ 有 n 个节点, 对称非负邻接矩阵为 $\mathbf{W} \in \mathbb{R}^{n \times n}$, 度矩阵为

$$\mathbf{D} = \text{diag}(d_1, \dots, d_n), \quad d_i = \sum_j w_{i,j}.$$

组合图拉普拉斯为 $\mathbf{L} = \mathbf{D} - \mathbf{W}$ 。一个 **图信号** (graph signal) 是给每个节点赋值的向量 $\mathbf{x} \in \mathbb{R}^n$ 。

图拉普拉斯的二次型满足

$$\mathbf{x}^\top \mathbf{L} \mathbf{x} = \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n w_{i,j} (x_i - x_j)^2. \quad (15.30)$$

展开右侧, 两个平方项分别给出 $\sum_i d_i x_i^2$ 的两份, 交叉项为

$$- \sum_{i=1}^n \sum_{j=1}^n w_{i,j} x_i x_j,$$

合并后便得到左侧。因此 $\mathbf{L}$ 对称半正定; 二次型越小, 强连接节点上的数值越接近。

由第 6 章的谱定理,

$$\mathbf{L} = \mathbf{U} \mathbf{\Lambda} \mathbf{U}^\top, \quad 0 = \lambda_0 \leq \lambda_1 \leq \dots \leq \lambda_{n-1}.$$

定义**图傅里叶变换** (graph Fourier transform)

$$\hat{\mathbf{x}}_g = \mathbf{U}^\top \mathbf{x}, \quad \mathbf{x} = \mathbf{U} \hat{\mathbf{x}}_g. \quad (15.31)$$

特征值小的特征向量在相邻节点间变化较缓, 特征值大的模式具有较高的图 Dirichlet 能量, 所以可把 λ_k 理解为图上的频率尺度。

15.6.2 规则环图把图谱接回 DFT

长度 N 的循环序列可以看作环图, 每个节点与左右邻居以权重 1 相连。其拉普拉斯作用为

$$(\mathbf{L}\mathbf{x})[t] = 2x[t] - x[(t-1) \bmod N] - x[(t+1) \bmod N].$$

代入复指数模式 $u_k[t] = N^{-1/2} e^{2\pi i k t / N}$,

$$\begin{aligned} (\mathbf{L}u_k)[t] &= (2 - e^{-2\pi i k / N} - e^{2\pi i k / N}) u_k[t] \\ &= \left(2 - 2 \cos \frac{2\pi k}{N}\right) u_k[t]. \end{aligned}$$

因此 DFT 复指数也是环图拉普拉斯的特征向量。规则序列频率与图频率并非两个无关定义; 在环图上, 它们由同一组模式连接。

这种对应也有边界。一般图的特征向量依赖节点连接和边权, 不同图上的第 k 个谱系数没有天然可比的物理频率。重特征值对应的特征子空间有多组正交基, 单个特征向量还存在符号或旋转不确定性。跨图比较时, 应比较由子空间、谱区间或图构造共同确定的对象, 不能直接把两个图的同

序号系数当作同一模式。

15.6.3 谱图滤波与局部多项式是同一个算子

给定标量函数 g ，可按矩阵函数定义图滤波器

$$g(\mathbf{L}) = \mathbf{U}g(\mathbf{\Lambda})\mathbf{U}^\top.$$

在图频域中，

$$\hat{\mathbf{y}}_{g,k} = g(\lambda_k)\hat{\mathbf{x}}_{g,k}.$$

这与规则序列滤波器按频率响应逐点缩放完全对应。若 g 是 K 次多项式，

$$\mathbf{y} = \sum_{r=0}^K \alpha_r \mathbf{L}^r \mathbf{x}, \quad (15.32)$$

则不必显式计算特征向量。一次乘 $\mathbf{L}$ 只在一跳邻域内聚合差异， $\mathbf{L}^r \mathbf{x}$ 只依赖至多 r 跳可达的节点，因此多项式谱滤波同时具有局部计算解释。

例如三节点路径图的拉普拉斯与一个集中在首节点的信号为

$$\mathbf{L} = \begin{bmatrix} 1 & -1 & 0 \\ -1 & 2 & -1 \\ 0 & -1 & 1 \end{bmatrix}, \quad \mathbf{x} = \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}.$$

取一次多项式 $g(\lambda) = 1 - \lambda/3$ ，则

$$g(\mathbf{L})\mathbf{x} = \left(\mathbf{I} - \frac{1}{3}\mathbf{L}\right)\mathbf{x} = \begin{bmatrix} 2/3 \\ 1/3 \\ 0 \end{bmatrix}.$$

首节点的一部分数值只传到一跳邻居，没有越过第二个节点；在谱坐标中，同一计算把每个系数乘以 $g(\lambda_k)$ 。该图的特征值为 0, 1, 3，相应响应为 1, 2/3, 0，所以最高图频率被消去。局部传播和谱缩放是同一个矩阵算子的两种读法。

这里的“卷积”是由选定图算子定义的谱滤波，不具备规则网格上的唯一核平移。改变图构造、归一化拉普拉斯或边权会改变特征模式与滤波器；即使函数 g 的公式相同，所得空间作用也可能不同。图信号方法保留了“在算子特征坐标中逐点缩放”的思想，却不能无条件继承普通序列的平移与跨图频率含义。

15.6.4 线性时不变状态递推产生卷积核

卷积把每个输入位置对当前输出的贡献一次写完，状态递推则逐时保存过去信息。考虑

$$\begin{aligned} \mathbf{s}_{t+1} &= \mathbf{A}\mathbf{s}_t + \mathbf{B}\mathbf{x}_t, \\ \mathbf{y}_t &= \mathbf{C}\mathbf{s}_t + \mathbf{D}\mathbf{x}_t, \end{aligned} \quad (15.33)$$

其中状态 $\mathbf{s}_t \in \mathbb{R}^{d_s}$ ，输入 $\mathbf{x}_t \in \mathbb{R}^{d_x}$ ，输出 $\mathbf{y}_t \in \mathbb{R}^{d_y}$ ，矩阵 $\mathbf{A} \in \mathbb{R}^{d_s \times d_s}$ 、 $\mathbf{B} \in \mathbb{R}^{d_s \times d_x}$ 、 $\mathbf{C} \in \mathbb{R}^{d_y \times d_s}$ 和 $\mathbf{D} \in \mathbb{R}^{d_y \times d_x}$ 不随 t 变化。递推一次、两次可以看到

$$\mathbf{s}_1 = \mathbf{A}\mathbf{s}_0 + \mathbf{B}\mathbf{x}_0, \quad \mathbf{s}_2 = \mathbf{A}^2\mathbf{s}_0 + \mathbf{A}\mathbf{B}\mathbf{x}_0 + \mathbf{B}\mathbf{x}_1.$$

这里用 $\mathbf{s}_t$ 表示状态、用 $\mathbf{x}_t$ 表示输入，是为了延续本章把 x 作为信号的约定。第 16 章讨论同一个线性状态过程时，改用 $\mathbf{x}_k$ 表示状态、用 $\mathbf{u}_k$ 表示输入；也就是说， $\mathbf{s}_t$ 对应该章的 $\mathbf{x}_k$ ， $\mathbf{x}_t$ 对应该章的 $\mathbf{u}_k$ ，时间下标 t 对应 k 。令该章的过程噪声为零，并取 $\mathbf{A}_k = \mathbf{A}$ 、 $\mathbf{B}_k = \mathbf{B}$ ，便得到这里相同的状态递推；这里的输出方程还显式保留了直接传递项 $\mathbf{D}\mathbf{x}_t$ 。对一般 t 归纳得到

$$\mathbf{s}_t = \mathbf{A}^t \mathbf{s}_0 + \sum_{\tau=0}^{t-1} \mathbf{A}^{t-1-\tau} \mathbf{B} \mathbf{x}_\tau. \quad (15.34)$$

归纳步骤只需把右侧乘 $\mathbf{A}$ 并加 $\mathbf{B}\mathbf{x}_t$ ，幂次与求和上界便同时向前移动一格。

代入输出方程，

$$\mathbf{y}_t = \mathbf{C}\mathbf{A}^t \mathbf{s}_0 + \mathbf{D}\mathbf{x}_t + \sum_{\tau=0}^{t-1} \mathbf{C}\mathbf{A}^{t-1-\tau} \mathbf{B} \mathbf{x}_\tau. \quad (15.35)$$

若初始状态为零，定义矩阵值脉冲响应

$$\mathbf{K}_0 = \mathbf{D}, \quad \mathbf{K}_r = \mathbf{C}\mathbf{A}^{r-1} \mathbf{B} \quad (r \geq 1), \quad (15.36)$$

便有

$$\mathbf{y}_t = \sum_{\tau=0}^t \mathbf{K}_{t-\tau} \mathbf{x}_\tau.$$

这正是因果卷积： $\mathbf{K}_r$ 描述 r 步之前的输入经过状态传播后对当前输出的作用。非零初态产生额外的自由响应 $\mathbf{C}\mathbf{A}^t \mathbf{s}_0$ ，它不是输入卷积的一部分。

标量递推

$$s_{t+1} = as_t + bx_t, \quad y_t = cs_t + dx_t$$

给出 $K_0 = d$ 以及 $K_r = ca^{r-1}b$ 。当 $|a| < 1$ 时，核随滞后几何衰减； $|a| > 1$ 时，远期输入的系数反而增长。这个观察只展示标量情形，矩阵系统的长期

行为还取决于特征值、非正规性和输入作用。相关稳定性条件将在第 16 章系统建立，本章不把一个形式展开当作稳定保证。

取 $a = 1/2$ 、 $b = c = 1$ 、 $d = 0$ 、 $s_0 = 0$ ，并把贯穿输入依次送入 $x_0 = 1, x_1 = 2, x_2 = 1$ 。逐步递推得到

$$y_0 = 0, \quad y_1 = 1, \quad y_2 = \frac{5}{2}, \quad y_3 = \frac{9}{4}.$$

另一方面，状态核为 $K_0 = 0, K_1 = 1, K_2 = 1/2, K_3 = 1/4$ ，所以

$$y_3 = K_3 x_0 + K_2 x_1 + K_1 x_2 = \frac{1}{4} + 1 + 1 = \frac{9}{4}.$$

递推与卷积给出相同结果，但输出从 y_0 开始包含一个由严格因果状态造成的零项；若 $d \neq 0$ ，当前输入还会通过 $K_0 = d$ 立即进入输出。

15.6.5 时变与输入依赖更新不再对应固定卷积

若状态矩阵随时间改变，

$$\mathbf{s}_{t+1} = \mathbf{A}_t \mathbf{s}_t + \mathbf{B}_t \mathbf{x}_t,$$

并令 $\mathbf{y}_t = \mathbf{C}_t \mathbf{s}_t + \mathbf{D}_t \mathbf{x}_t$ ，从时刻 τ 传播到 t 的系数变成有序乘积

$$\Phi(t, \tau + 1) = \mathbf{A}_{t-1} \mathbf{A}_{t-2} \cdots \mathbf{A}_{\tau+1}.$$

当 $t = \tau + 1$ 时，这个乘积按约定为单位矩阵。输出对输入的核依赖两个绝对时刻，而不只依赖滞后 $t - \tau$ ：

$$\mathbf{K}_{t,t} = \mathbf{D}_t, \quad \mathbf{K}_{t,\tau} = \mathbf{C}_t \Phi(t, \tau + 1) \mathbf{B}_\tau \quad (0 \leq \tau < t).$$

这仍是线性输入输出关系，却不再平移不变，因而不是一个固定核的卷积。矩阵乘法次序也不能交换；较晚时刻的状态转移必须写在左侧。

若 $\mathbf{A}_t$ 或门控系数本身依赖 $\mathbf{x}_t$ 或 $\mathbf{s}_t$ ，展开后的“核”还会依赖当前输入轨迹。此时系统通常是非线性的，叠加原理失效。可以在固定轨迹附近线性化，得到局部的时变响应，但它不能作为对所有输入都成立的卷积核。区分固定线性时不变核、两时刻的线性时变核和输入依赖的动态作用，是从本章进入动力系统分析时必须保留的边界。

15.7 本章小结

有序输入上的线性作用之所以可以得到特殊算法，是因为平移结构让同一个脉冲响应在不同位置复用。线性与平移不变共同推出卷积；零延拓产生线性卷积，周期延拓产生循环卷积，相关运算则改变核方向与复共轭约定。

边界、翻转和裁剪属于算子定义，不能留给实现任意决定。

同一次卷积可以用矩阵、多项式或频率坐标表示。多项式乘积把卷积写成系数乘法，模 $z^N - 1$ 解释循环回绕；DFT 在单位根处求值，并用正交复指数恢复系数。卷积定理把循环卷积化为频域逐点乘法，线性卷积只有在补零长度不小于完整输出长度时才能使用这一结果。FFT 利用单位根递归，Toom-Cook 利用一般求值插值，Winograd 类方法利用余数分解和中国剩余定理。三者都重新组织计算，却具有不同的变换成本、数值误差和适用边界。

频率表示还说明信息在哪里丢失。滤波器的频率响应给出各模式的缩放；采样会周期复制频谱，副本重叠后便发生混叠。抗混叠滤波可以在下采样前限制频带，却不能保留已被滤除的细节。图拉普拉斯谱把“变化模式”推广到不规则关系，但模式依赖具体图，不能在不同图之间按序号直接对应。

线性时不变状态递推展开后产生矩阵值卷积核，核的第 r 项是输入经过 r 步状态传播后对输出的作用。非零初态、时变矩阵和输入依赖更新分别引入自由响应、两时刻核与非线性动态，不能继续套用固定卷积。第 16 章将从同一个状态过程出发，研究轨迹、离散化、稳定性、随机扰动和不完全观测下的状态估计。

动力系统与状态估计

第 6 章已经说明，矩阵会沿不同方向放大或压缩向量；第 8 章建立了条件分布与条件高斯计算；第 9 章则把相关观测和随机更新放进时间序列。这些工具还没有回答一个共同问题：当一个系统把过去压缩进当前状态，并继续随时间演化时，初值、输入、噪声和观测分别决定了什么？

第 15 章从输入到输出的整体关系出发，把线性时不变递推展开成卷积核。该章以 $\mathbf{s}_t$ 、 $\mathbf{x}_t$ 、 $\mathbf{y}_t$ 分别表示状态、输入和输出；本章为突出状态估计，把它们依次改记为 $\mathbf{x}_k$ 、 $\mathbf{u}_k$ 、 $\mathbf{y}_k$ ，并先采用没有直接输入输出通道的观测方程。本章转而保留递推中的内部状态。状态不是对历史的逐项存档，而是足以继续预测未来的当前摘要。给定初值和输入，状态方程决定一条轨迹；加入过程噪声后，它决定轨迹的分布；只能看到带噪观测时，还要用观测历史形成状态的条件分布。这三个对象不能混用。

贯穿前五节的离散线性状态模型为

$$\mathbf{x}_{k+1} = \mathbf{A}_k \mathbf{x}_k + \mathbf{B}_k \mathbf{u}_k + \mathbf{w}_k, \quad (16.1)$$

$$\mathbf{y}_k = \mathbf{C}_k \mathbf{x}_k + \mathbf{v}_k. \quad (16.2)$$

其中 $\mathbf{x}_k \in \mathbb{R}^d$ 是状态， $\mathbf{u}_k \in \mathbb{R}^m$ 是给定输入， $\mathbf{y}_k \in \mathbb{R}^p$ 是观测。本章先令噪声为零，研究方程怎样产生轨迹、怎样数值计算，以及扰动会不会衰减；随后恢复噪声，推导有限时域的预测、Kalman 滤波与 RTS 平滑。

后半章改变问题对象：随机参数更新的长期趋势形成平均动力学，离散随机增量进一步推进到连续时间，Hamilton 动力学则研究怎样保持能量与体积。轨迹稳定、状态估计准确、随机更新收敛和采样分布正确分别需要不同条件；本章将把这些条件放在相应结论附近。

16.1 差分方程与常微分方程

16.1.1 状态把过去压缩成当前记忆

先看一个带泄漏的标量记忆。给定输入序列 (u_k) , 令

$$x_{k+1} = ax_k + bu_k, \quad x_0 \text{ 给定.} \quad (16.3)$$

反复代入可得

$$x_k = a^k x_0 + \sum_{j=0}^{k-1} a^{k-1-j} bu_j. \quad (16.4)$$

当前状态把初值和全部旧输入压缩成一个数。当 $|a| < 1$ 时, 较早输入的权重按几何速度衰减; 当 $|a| > 1$ 时, 同一递推会放大早期扰动。因此, “能够写成卷积”只说明计算结构, 并不保证记忆稳定。

若观察间隔缩短到 Δt , 可把泄漏系数写成 $a = 1 - \lambda \Delta t$, 输入系数写成 $b = \Delta t$ 。两边减去 x_k 并除以 Δt , 形式上得到

$$\frac{x_{k+1} - x_k}{\Delta t} = -\lambda x_k + u_k.$$

当输入来自连续函数 $u(t)$ 且极限存在时, 对应的连续时间模型是

$$\dot{x}(t) = -\lambda x(t) + u(t). \quad (16.5)$$

差分方程直接规定相邻时刻的更新, 常微分方程 (ordinary differential equation, ODE) 则规定每个时刻的瞬时变化率。从后者得到可计算递推还要选择离散化方法, 不能把式 (16.3) 与式 (16.5) 视为天然相同。

16.1.2 初值问题的解需要存在性与唯一性

一般一阶 ODE 初值问题写成

$$\dot{\mathbf{x}}(t) = \mathbf{f}(t, \mathbf{x}(t), \mathbf{u}(t)), \quad \mathbf{x}(t_0) = \mathbf{x}_0. \quad (16.6)$$

给定输入 $\mathbf{u}$ 以后, 可以把右侧看成 $(t, \mathbf{x})$ 的函数。这里的 **绝对连续曲线** (absolutely continuous curve) 允许导数只在几乎处处存在, 但要求存在可积函数 $\mathbf{v}$ 使 $\mathbf{x}(t) = \mathbf{x}(t_0) + \int_{t_0}^t \mathbf{v}(s) ds$ 。因此, ODE 的解不是任意满足局部斜率的点集, 而是一条绝对连续曲线, 并在几乎处处取 $\mathbf{v}(t) = \mathbf{f}(t, \mathbf{x}(t), \mathbf{u}(t))$, 等价地满足积分方程

$$\mathbf{x}(t) = \mathbf{x}_0 + \int_{t_0}^t \mathbf{f}(s, \mathbf{x}(s), \mathbf{u}(s)) ds. \quad (16.7)$$

定理 16.1 局部存在唯一性 若 $f(t, \mathbf{x}, \mathbf{u}(t))$ 在 $(t_0, \mathbf{x}_0)$ 附近关于 t 连续, 并且关于 $\mathbf{x}$ 局部 Lipschitz, 则存在包含 t_0 的时间区间, 使初值问题 (16.6) 在该区间上有唯一解。

证明. 记 $\mathbf{g}(t, \mathbf{x}) = f(t, \mathbf{x}, \mathbf{u}(t))$ 。取 $a, b > 0$, 使闭区域

$$[t_0 - a, t_0 + a] \times \{\mathbf{x} : \|\mathbf{x} - \mathbf{x}_0\|_2 \leq b\}$$

包含在定理的适用邻域内。记 $\mathbf{g}$ 在该区域上的上界为 M , 关于 $\mathbf{x}$ 的 Lipschitz 常数为 L 。选择 $h > 0$ 使

$$h \leq a, \quad Mh \leq b, \quad Lh < 1,$$

并令 $I = [t_0 - h, t_0 + h]$ 。在连续函数空间

$$\mathcal{X} = \{\mathbf{z} \in C(I) : \|\mathbf{z} - \mathbf{x}_0\|_\infty \leq b\}$$

是完备空间 $C(I, \mathbb{R}^d)$ 的闭子集, 因而仍然完备。在 $\mathcal{X}$ 上定义 Picard 算子

$$(\mathcal{T}\mathbf{z})(t) = \mathbf{x}_0 + \int_{t_0}^t \mathbf{g}(s, \mathbf{z}(s)) \mathrm{d}s.$$

对任意 $\mathbf{z} \in \mathcal{X}$ 和 $t \in I$,

$$\|(\mathcal{T}\mathbf{z})(t) - \mathbf{x}_0\|_2 \leq M|t - t_0| \leq Mh \leq b,$$

所以 $\mathcal{T}$ 把 $\mathcal{X}$ 映回自身。对任意两条候选曲线,

$$\|\mathcal{T}\mathbf{z}_1 - \mathcal{T}\mathbf{z}_2\|_\infty \leq Lh\|\mathbf{z}_1 - \mathbf{z}_2\|_\infty.$$

这里 h 是区间相对于 t_0 的半宽, 因而压缩因子是固定常数 Lh 。由 $Lh < 1$, $\mathcal{T}$ 是压缩映射。压缩映射定理给出唯一不动点, 而不动点正是积分方程 (16.7) 的解。■

局部 Lipschitz 条件服务于唯一性。只有连续性时, 解可能存在却不唯一。例如 $\dot{x} = \sqrt{|x|}$, $x(0) = 0$ 既允许恒为零的解, 也允许先停留一段时间再离开零点的解。局部解也不自动延伸到任意时间。方程 $\dot{x} = x^2$ 从 $x(0) = 1$ 出发的解为 $x(t) = 1/(1-t)$, 它在 $t = 1$ 有限时间爆炸。

若 f 关于 $\mathbf{x}$ 全局 Lipschitz, 并且 $\|f(t, \mathbf{0}, \mathbf{u}(t))\|$ 在有限时间区间可积, Gronwall 不等式可排除有限时间爆炸, 从而把解延伸到所需区间。更一般地, 也可以用径向无界的能量函数证明轨迹留在有界集合。因此, 全局解依赖增长控制, 而不只是局部导数存在。

16.1.3 线性系统的变参数公式

连续时间线性时不变系统写成

$$\dot{\mathbf{x}}(t) = \mathbf{A}\mathbf{x}(t) + \mathbf{B}\mathbf{u}(t). \quad (16.8)$$

第 6.4 节定义的矩阵指数满足

$$\frac{d}{dt}e^{t\mathbf{A}} = \mathbf{A}e^{t\mathbf{A}}, \quad e^{0\mathbf{A}} = \mathbf{I}.$$

令 $\mathbf{z}(t) = e^{-t\mathbf{A}}\mathbf{x}(t)$, 乘积求导给出

$$\dot{\mathbf{z}}(t) = e^{-t\mathbf{A}}\mathbf{B}\mathbf{u}(t).$$

积分后再乘回 $e^{t\mathbf{A}}$, 得到

$$\mathbf{x}(t) = e^{(t-t_0)\mathbf{A}}\mathbf{x}_0 + \int_{t_0}^t e^{(t-s)\mathbf{A}}\mathbf{B}\mathbf{u}(s) ds. \quad (16.9)$$

第一项传播初值, 第二项累计各时刻输入经过剩余时间后的影响。这正是连续状态方程产生卷积核的来源。为核对这个公式, 记右侧为 $\tilde{\mathbf{x}}(t)$ 。代入 $t = t_0$ 可得 $\tilde{\mathbf{x}}(t_0) = \mathbf{x}_0$; 再用积分上限求导,

$$\dot{\tilde{\mathbf{x}}}(t) = \mathbf{A}\tilde{\mathbf{x}}(t) + \mathbf{B}\mathbf{u}(t).$$

因此, 只要 $\mathbf{u}$ 局部可积, 式 (16.9) 就给出积分意义下的解; 若 $\mathbf{u}$ 连续, 它还是经典解。线性方程的唯一性说明这条轨迹不是候选解之一, 而是给定初值对应的唯一解。

标量泄漏方程 (16.5) 取 $\lambda > 0$ 且 $u(t) \equiv u_0$ 时, 式 (16.9) 化为

$$x(t) = e^{-\lambda(t-t_0)}x_0 + \frac{1 - e^{-\lambda(t-t_0)}}{\lambda}u_0.$$

初值的影响指数衰减, 状态则趋向 u_0/λ 。这一区分将在稳定性分析中反复出现: 齐次偏差可以趋零, 而持续输入下的状态不必趋向原点。

若系数随时间变化,

$$\dot{\mathbf{x}}(t) = \mathbf{A}(t)\mathbf{x}(t) + \mathbf{B}(t)\mathbf{u}(t),$$

需要引入**状态转移矩阵** (state transition matrix) $\Phi(t, s)$, 它满足

$$\frac{\partial}{\partial t}\Phi(t, s) = \mathbf{A}(t)\Phi(t, s), \quad \Phi(s, s) = \mathbf{I}. \quad (16.10)$$

相应解为

$$\mathbf{x}(t) = \Phi(t, t_0)\mathbf{x}_0 + \int_{t_0}^t \Phi(t, s)\mathbf{B}(s)\mathbf{u}(s) \, ds. \quad (16.11)$$

状态转移矩阵满足组合律

$$\Phi(t, r)\Phi(r, s) = \Phi(t, s),$$

但一般不等于

$$\exp\left(\int_s^t \mathbf{A}(\tau) \, d\tau\right).$$

只有不同时间的矩阵彼此交换等附加条件成立时, 才能把时序乘积压成普通矩阵指数。

16.1.4 移动区间上的投影也能形成状态

状态不必来自物理位置或速度。若希望在每个时刻 t 用有限组基函数近似过去输入 $\mathbf{u}|_{[0,t]}$, 可以把有限维分析坐标记为状态 $\mathbf{x}(t)$ 。例如在随 t 变化的内积

$$\langle f, g \rangle_t = \int_0^t f(s)g(s)w_t(s) \, ds$$

下, 记基函数为 $\phi_1^{(t)}, \dots, \phi_d^{(t)}$ 。若这些基函数关于 $\langle \cdot, \cdot \rangle_t$ 正交归一, 则内积 $\langle \mathbf{u}, \phi_\ell^{(t)} \rangle_t$ 就是投影展开系数; 对一般基, 令

$$G_{i,j}(t) = \langle \phi_i^{(t)}, \phi_j^{(t)} \rangle_t, \quad c_i(t) = \langle \mathbf{u}, \phi_i^{(t)} \rangle_t,$$

实际投影坐标 $\mathbf{a}(t)$ 应满足 Gram 方程 $\mathbf{G}(t)\mathbf{a}(t) = \mathbf{c}(t)$ 。因此, 下文先研究容易直接求导的分析坐标 $c_\ell(t)$; 它们关于 t 的变化不只来自新输入。为了看清各项, 固定窗口宽度 $T > 0$, 并写

$$c_\ell(t) = \int_{t-T}^t u(s)\phi_\ell(t, s)w(t, s) \, ds.$$

在被积函数及其 t 方向偏导连续等条件下, Leibniz 法则给出

$$\begin{aligned} \dot{c}_\ell(t) &= u(t)\phi_\ell(t, t)w(t, t) - u(t-T)\phi_\ell(t, t-T)w(t, t-T) \\ &\quad + \int_{t-T}^t u(s)\partial_t[\phi_\ell(t, s)w(t, s)] \, ds. \end{aligned} \quad (16.12)$$

三项依次表示新输入进入窗口、旧输入移出窗口, 以及窗口内部的基函数或权重随时间改变。

取均匀权重并保留常数与一次矩,

$$c_0(t) = \frac{1}{T} \int_{t-T}^t u(s) \, ds, \quad c_1(t) = \frac{2}{T^2} \int_{t-T}^t (s-t+T)u(s) \, ds.$$

直接使用式 (16.12) 可得

$$\dot{c}_0(t) = \frac{u(t) - u(t-T)}{T}, \quad \dot{c}_1(t) = \frac{2}{T}u(t) - \frac{2}{T}c_0(t).$$

第二个递推在 (c_0, c_1) 与当前输入之间闭合，但第一个仍需要窗口左端的 $u(t-T)$ 。这说明“用有限个分析坐标表示历史”和“这些坐标形成有限维 Markov 状态”不是同一件事；还需要基、权重或额外状态使边界项也能由当前状态表示。

HiPPO 一类历史压缩方法利用的正是这一结构：状态坐标被设计为移动历史上的投影坐标，而不是任意循环网络的隐藏变量；基不正交时，还需把分析坐标通过 Gram 方程转换为投影坐标。投影保留什么由基、权重和窗口决定。有限维状态只能精确保留有限维子空间中的历史；对一般输入，它提供的是带明确度量的近似，不能解释为无损记忆全部过去。

16.2 离散化与递推组合

16.2.1 数值方法近似的是流映射

设一般非自治 ODE 为 $\dot{\mathbf{x}} = \mathbf{f}(t, \mathbf{x})$ 。从时刻 t_k 到 $t_{k+1} = t_k + h$ 的精确解定义两时刻流映射

$$\mathbf{x}_{k+1} = \varphi_{t_{k+1}, t_k}(\mathbf{x}_k).$$

数值方法用依赖起始时刻的可计算映射 Ψ_{h, t_k} 近似 φ_{t_{k+1}, t_k} 。对自治方程，这两个映射才可分别简写为 φ_h 与 Ψ_h 。一步局部截断误差考察从精确起点走一步的差，全局误差则考察许多近似步骤累计后的轨迹差。局部误差高一阶并不自动给出全局结论，还要控制误差在后续递推中的传播。

显式 Euler 法用当前斜率近似整个区间：

$$\mathbf{x}_{k+1} = \mathbf{x}_k + h\mathbf{f}(t_k, \mathbf{x}_k). \quad (16.13)$$

若精确解二阶可微，Taylor 展开说明其局部截断误差为 $O(h^2)$ ；在有限时间区间、Lipschitz 条件和解足够光滑时，全局误差为 $O(h)^1$ 。

经典四阶 Runge-Kutta 法在同一步内计算四个斜率：

$$\begin{aligned} \mathbf{k}_1 &= \mathbf{f}(t_k, \mathbf{x}_k), \\ \mathbf{k}_2 &= \mathbf{f}(t_k + h/2, \mathbf{x}_k + h\mathbf{k}_1/2), \\ \mathbf{k}_3 &= \mathbf{f}(t_k + h/2, \mathbf{x}_k + h\mathbf{k}_2/2), \\ \mathbf{k}_4 &= \mathbf{f}(t_k + h, \mathbf{x}_k + h\mathbf{k}_3), \\ \mathbf{x}_{k+1} &= \mathbf{x}_k + \frac{h}{6}(\mathbf{k}_1 + 2\mathbf{k}_2 + 2\mathbf{k}_3 + \mathbf{k}_4). \end{aligned}$$

¹ E. Hairer, S. P. Nørsett, G. Wanner, *Solving Ordinary Differential Equations I: Nonstiff Problems*, Springer, 1993, 2nd ed.

在相应光滑条件下, 它的局部误差为 $O(h^5)$, 全局误差为 $O(h^4)$ 。阶数比较固定的是步长趋零时的渐近误差; 一次函数评估成本、刚性和有限精度仍会改变实际选择。

定理 16.2 Euler 法的有限时域全局误差 设 $f(t, \mathbf{x})$ 在包含精确轨迹与 Euler 轨迹的区域内关于 $\mathbf{x}$ 具有 Lipschitz 常数 L , 精确解二阶连续可微且 $\|\dot{\mathbf{x}}(t)\|_2 \leq M$ 。若 $t_k = t_0 + kh \leq t_0 + T$, Euler 法从精确初值出发, 则当 $L > 0$ 时

$$\|\mathbf{x}_k - \mathbf{x}(t_k)\|_2 \leq \frac{Mh}{2L}(e^{LT} - 1).$$

当 $L = 0$ 时, 右侧相应为 $MTh/2$ 。因此固定有限时域上的全局误差为 $O(h)$ 。

证明. Taylor 公式给出

$$\mathbf{x}(t_{k+1}) = \mathbf{x}(t_k) + h\mathbf{f}(t_k, \mathbf{x}(t_k)) + \boldsymbol{\tau}_k, \quad \|\boldsymbol{\tau}_k\|_2 \leq \frac{M}{2}h^2.$$

令 $\mathbf{e}_k = \mathbf{x}_k - \mathbf{x}(t_k)$ 。将精确一步与 Euler 一步相减, 并使用 Lipschitz 条件,

$$\|\mathbf{e}_{k+1}\|_2 \leq (1 + Lh)\|\mathbf{e}_k\|_2 + \frac{M}{2}h^2.$$

由于 $\mathbf{e}_0 = \mathbf{0}$, 递归展开后得到

$$\|\mathbf{e}_k\|_2 \leq \frac{M}{2}h^2 \sum_{j=0}^{k-1} (1 + Lh)^j.$$

当 $L > 0$ 时, 几何和等于 $[(1 + Lh)^k - 1]/(Lh)$, 再由 $(1 + Lh)^k \leq e^{Lkh} \leq e^{LT}$ 得到结论。当 $L = 0$ 时直接求和, 并用 $kh \leq T$ 即可。■

证明中的递推不等式就是本节所需的离散 Grönwall 论证。它还说明为何局部 $O(h^2)$ 只得到全局 $O(h)$: 固定时间内约有 T/h 个局部误差需要累积, 而动态的 Lipschitz 因子控制这些误差随后被放大的程度。

16.2.2 零阶保持给出线性系统的精确离散

对式 (16.8), 假设区间 $[kh, (k+1)h]$ 内输入保持常数 $\mathbf{u}_k$ 。把式 (16.9) 应用于一个采样区间, 得到

$$\mathbf{x}_{k+1} = \mathbf{A}_h \mathbf{x}_k + \mathbf{B}_h \mathbf{u}_k, \quad (16.14)$$

$$\mathbf{A}_h := e^{h\mathbf{A}}, \quad \mathbf{B}_h := \int_0^h e^{(h-s)\mathbf{A}} \mathbf{B} \, ds. \quad (16.15)$$

这称为**零阶保持** (zero-order hold, ZOH) 离散化。它对分段常数输入精确, 误差来自输入保持假设和数值计算矩阵指数, 而不是 Euler 截断。若 $\mathbf{A}$ 可逆, 可写 $\mathbf{B}_h = \mathbf{A}^{-1}(\mathbf{e}^{h\mathbf{A}} - \mathbf{I})\mathbf{B}$, 但积分定义在 $\mathbf{A}$ 奇异时仍然有效, 也更能显示成立范围。

示例 16.3 连续稳定与数值稳定不是一回事 考虑

$$\dot{x}(t) = -\lambda x(t) + u, \quad \lambda > 0,$$

并令区间内 u 为常数。精确离散为

$$x_{k+1} = e^{-\lambda h} x_k + \frac{1 - e^{-\lambda h}}{\lambda} u.$$

Euler 离散为

$$x_{k+1} = (1 - \lambda h)x_k + hu.$$

连续齐次系统对每个 $\lambda > 0$ 都指数衰减。Euler 齐次递推却只有在

$$|1 - \lambda h| < 1, \quad \text{即} \quad 0 < h < \frac{2}{\lambda},$$

时渐近稳定。步长过大造成的发散属于数值更新不稳定, 不能据此断言原连续系统不稳定。

这个例子也展示了截断误差与稳定范围的区别。当 h 很小时, $e^{-\lambda h} = 1 - \lambda h + O(h^2)$, Euler 一步近似精确; 当 $h > 2/\lambda$ 时, 即使局部公式仍可计算, 反复组合也会放大误差。

16.2.3 仿射递推可以用前缀扫描组合

考虑时变仿射递推

$$\mathbf{x}_{k+1} = \mathbf{A}_k \mathbf{x}_k + \mathbf{b}_k. \quad (16.16)$$

把每一步表示为二元组 $g_k = (\mathbf{A}_k, \mathbf{b}_k)$, 并定义“后一步接在前一步之后”的组合

$$(\mathbf{A}_2, \mathbf{b}_2) \circ (\mathbf{A}_1, \mathbf{b}_1) = (\mathbf{A}_2 \mathbf{A}_1, \mathbf{A}_2 \mathbf{b}_1 + \mathbf{b}_2). \quad (16.17)$$

直接展开三次复合可得

$$\begin{aligned} g_3 \circ (g_2 \circ g_1) &= (\mathbf{A}_3 \mathbf{A}_2 \mathbf{A}_1, \mathbf{A}_3 \mathbf{A}_2 \mathbf{b}_1 + \mathbf{A}_3 \mathbf{b}_2 + \mathbf{b}_3) \\ &= (g_3 \circ g_2) \circ g_1, \end{aligned}$$

所以该运算满足结合律。由此, 所有前缀 $g_{k-1} \circ \cdots \circ g_0$ 可以用并行前缀扫描组织, 再作用于 $\mathbf{x}_0$ 得到每个状态。

结合律不等于交换律。一般有

$$g_2 \circ g_1 \neq g_1 \circ g_2,$$

因为矩阵乘法次序不同, 偏置所经历的后续变换也不同。例如令 $g_1(\mathbf{x}) = \text{diag}(2, 1)\mathbf{x}$, $g_2(\mathbf{x}) = \mathbf{x} + (1, 0)^\top$ 。从 $\mathbf{x} = \mathbf{0}$ 出发,

$$(g_2 \circ g_1)(\mathbf{0}) = (1, 0)^\top, \quad (g_1 \circ g_2)(\mathbf{0}) = (2, 0)^\top.$$

同一个伸缩与平移只因交换次序就得到不同结果。扫描算法可以改变括号位置以增加并行度, 不能改变时间顺序。输入依赖或非线性更新若不形成封闭的结合运算, 也不能只因“看起来像递推”就使用同一扫描结构。

16.2.4 误差传播取决于动态本身

设精确一步映射为 φ_{t_{k+1}, t_k} , 数值映射为 Ψ_{h, t_k} , 并令全局误差为 $\mathbf{e}_k = \hat{\mathbf{x}}_k - \mathbf{x}(t_k)$ 。若每个 Ψ_{h, t_k} 在相关区域内关于状态的 Lipschitz 常数都不超过 L_h , 并且沿精确轨迹的一步局部截断误差满足

$$\|\Psi_{h, t_k}(\mathbf{x}(t_k)) - \varphi_{t_{k+1}, t_k}(\mathbf{x}(t_k))\| \leq \tau_h,$$

则把误差拆成“数值映射传播已有误差”与“从精确起点产生一步误差”两项, 得到

$$\|\mathbf{e}_{k+1}\| \leq L_h \|\mathbf{e}_k\| + \tau_h.$$

反复展开得到

$$\|\mathbf{e}_k\| \leq L_h^k \|\mathbf{e}_0\| + \tau_h \sum_{j=0}^{k-1} L_h^j.$$

当动态收缩时, 旧误差会衰减; 当动态强烈放大时, 再高的局部阶数也可能被长时传播削弱。因此, 数值精度、数值稳定域与真实系统稳定性必须分别检查。

16.3 稳定性与敏感性

16.3.1 稳定性描述初值附近的轨迹

考虑自治系统 $\dot{\mathbf{x}} = \mathbf{f}(\mathbf{x})$, 并设 $\mathbf{x}^*$ 满足 $\mathbf{f}(\mathbf{x}^*) = \mathbf{0}$ 。它称为平衡点。平衡点在 Lyapunov 意义下**稳定**, 是指对每个 $\varepsilon > 0$ 都存在 $\delta > 0$, 使 $\|\mathbf{x}(0) - \mathbf{x}^*\| < \delta$ 蕴含

$$\|\mathbf{x}(t) - \mathbf{x}^*\| < \varepsilon \quad \text{对所有 } t \geq 0.$$

若它稳定, 并且足够近的轨迹还满足 $\mathbf{x}(t) \rightarrow \mathbf{x}^*$, 就称为**渐近稳定**。若存在 $r, C, \alpha > 0$, 使每个满足 $\|\mathbf{x}(0) - \mathbf{x}^*\|_2 < r$ 的初值都满足

$$\|\mathbf{x}(t) - \mathbf{x}^*\|_2 \leq C e^{-\alpha t} \|\mathbf{x}(0) - \mathbf{x}^*\|_2, \quad t \geq 0,$$

则称该平衡点局部指数稳定。常数 C, α 必须对这个邻域内的初值统一; 若同一界对任意初值成立, 则称为全局指数稳定。

稳定只要求轨迹不离开, 渐近稳定还要求轨迹回到平衡点。系统 $\dot{\mathbf{x}} = 0$ 的每个点都稳定, 却没有一个孤立点吸引邻近轨迹。稳定性也默认输入固定为所声明的值。有外部输入时, 需要另问有界输入产生多大状态响应, 不能把零输入稳定直接改写成任意输入下状态趋零。

16.3.2 线性系统由谱决定长期行为

对离散齐次系统

$$\mathbf{x}_{k+1} = \mathbf{A}\mathbf{x}_k, \quad (16.18)$$

有 $\mathbf{x}_k = \mathbf{A}^k \mathbf{x}_0$ 。

定理 16.4 离散线性系统的渐近稳定性 系统 (16.18) 的原点全局渐近稳定, 当且仅当谱半径

$$\rho(\mathbf{A}) = \max_{\lambda \in \text{spec}(\mathbf{A})} |\lambda| < 1.$$

证明. 把 $\mathbf{A}$ 在复数域写成 Jordan 形式 $\mathbf{A} = \mathbf{V}\mathbf{J}\mathbf{V}^{-1}$ 。一个大小为 r 、特征值为 λ 的 Jordan 块满足

$$\mathbf{J}_\lambda^k = \sum_{j=0}^{r-1} \binom{k}{j} \lambda^{k-j} \mathbf{N}^j,$$

其中 $\mathbf{N}$ 为幂零矩阵。若 $|\lambda| < 1$, 多项式因子 k^j 仍被几何衰减压过, 所以每个 Jordan 块趋零, 进而 $\mathbf{A}^k \rightarrow \mathbf{0}$ 。这给出全局渐近稳定。

反过来, 若存在 $|\lambda| > 1$ 的特征值, 沿相应特征向量的状态会增长。若 $|\lambda| = 1$, 沿普通特征向量的状态至少不趋零; 若相应 Jordan 块非平凡, 还会出现多项式增长。因此渐近稳定要求全部特征值严格位于单位圆内。■

定理 16.5 连续线性系统的指数稳定性 连续线性系统 $\dot{\mathbf{x}} = \mathbf{A}\mathbf{x}$ 的原点全局指数稳定, 当且仅当 $\mathbf{A}$ 的所有特征值实部严格为负。满足该条件的矩阵称为 Hurwitz 矩阵。

证明. 对大小为 r 、特征值为 λ 的 Jordan 块,

$$e^{t(\lambda I + N)} = e^{\lambda t} \sum_{j=0}^{r-1} \frac{t^j}{j!} N^j.$$

若所有 $\operatorname{Re}(\lambda) < 0$, 任选小于 $-\max_{\lambda} \operatorname{Re}(\lambda)$ 的 $\alpha > 0$, 各有限次多项式因子都可被 $Ce^{-\alpha t}$ 控制. 乘回换基矩阵后便有 $\|e^{tA}\| \leq Ce^{-\alpha t}$, 所以原点全局指数稳定。

反过来, 若某个特征值实部为正, 沿对应实不变子空间存在指数增长的解; 若实部为零, 普通特征向量产生不衰减的振荡或常值解, 非平凡 Jordan 块还会带来多项式增长. 这些情形都不可能满足统一指数衰减界。 ■

离散系统检查单位圆, 连续系统检查复平面的左半部; 两者不能直接交换判据。

16.3.3 Lyapunov 函数把稳定性转成标量下降

Lyapunov 函数 (Lyapunov function) 是沿轨迹衡量偏离平衡点的标量函数. 它不必等于物理能量, 关键是对状态正定, 并沿系统演化下降。

下面的判据把这一思路落实为局部与全局稳定性条件²。

² H. K. Khalil, *Nonlinear Systems*, Prentice Hall, 2002, 3rd ed.

定理 16.6 连续时间 Lyapunov 判据 设 $\mathbf{x}^* = \mathbf{0}$ 是 $\dot{\mathbf{x}} = \mathbf{f}(\mathbf{x})$ 的平衡点, 且 $\mathbf{f}$ 在该点的某邻域内局部 Lipschitz, 使初值问题具有唯一的最大解. 若该邻域内存在连续可微函数 V , 满足

$$V(\mathbf{0}) = 0, \quad V(\mathbf{x}) > 0 \quad (\mathbf{x} \neq \mathbf{0}),$$

并且沿轨迹

$$\dot{V}(\mathbf{x}) = \nabla V(\mathbf{x})^\top \mathbf{f}(\mathbf{x}) \leq 0,$$

则原点稳定. 若进一步对 $\mathbf{x} \neq \mathbf{0}$ 有 $\dot{V}(\mathbf{x}) < 0$, 则原点局部渐近稳定. 若这些条件全局成立, $\mathbf{f}$ 在 $\mathbb{R}^d$ 上局部 Lipschitz, 且 $V(\mathbf{x}) \rightarrow \infty$ 随 $\|\mathbf{x}\| \rightarrow \infty$ 成立, 则所有最大解都可正向延拓到任意时间, 稳定性与吸引性为全局结论。

证明. 固定一个足够小的 ε , 使闭球包含在定理适用邻域内. 球面 $\|\mathbf{x}\| = \varepsilon$ 是紧集, 而 V 在其上连续且正, 故最小值 $c_\varepsilon > 0$. 由 $V(\mathbf{0}) = 0$ 与连续性, 可取 $\delta > 0$ 使 $\|\mathbf{x}(0)\| < \delta$ 蕴含 $V(\mathbf{x}(0)) < c_\varepsilon$. 由于 $\dot{V} \leq 0$, 轨迹不可能到达 $V \geq c_\varepsilon$ 的球面, 所以始终留在 ε 球内, 得到稳定性。

若 $\dot{V}$ 负定, 轨迹限制在一个紧的正子水平集 K 内. 反设轨迹不趋近原点, 则存在 $\varepsilon_0 > 0$ 及趋向无穷的时刻序列, 使 $\|\mathbf{x}(t_j)\| \geq \varepsilon_0$. 由于 $\mathbf{f}$ 在 K

上有界, 记 $M = \sup_{\mathbf{x} \in K} \|\mathbf{f}(\mathbf{x})\|$; 每次轨迹达到半径 ε_0 后, 都至少在长度 $\varepsilon_0/(2M)$ 的时间内留在闭环带 $\varepsilon_0/2 \leq \|\mathbf{x}\| \leq \sup_{\mathbf{z} \in K} \|\mathbf{z}\|$ 中。该环带紧且不含原点, 连续函数 $-\dot{V}$ 在其上有严格正的下界。选取互不相交的这些停留区间, V 便会减少无穷大的总量, 与 $V \geq 0$ 矛盾。因此轨迹趋向原点。径向无界性保证全局子水平集有界, 轨迹无法在有限时间逃向无穷远, 从而把同一论证扩展到任意初值。 ■

对线性系统, 常取二次函数 $V(\mathbf{x}) = \mathbf{x}^\top \mathbf{P} \mathbf{x}$ 。沿 $\dot{\mathbf{x}} = \mathbf{A} \mathbf{x}$ 有

$$\dot{V}(\mathbf{x}) = \mathbf{x}^\top (\mathbf{A}^\top \mathbf{P} + \mathbf{P} \mathbf{A}) \mathbf{x}. \quad (16.19)$$

定理 16.7 线性 Lyapunov 方程 矩阵 $\mathbf{A}$ 为 Hurwitz 矩阵, 当且仅当对每个 $\mathbf{Q} > \mathbf{0}$, 存在唯一 $\mathbf{P} > \mathbf{0}$ 满足

$$\mathbf{A}^\top \mathbf{P} + \mathbf{P} \mathbf{A} = -\mathbf{Q}. \quad (16.20)$$

证明. 若 $\mathbf{A}$ 为 Hurwitz 矩阵, 定义

$$\mathbf{P} = \int_0^\infty \mathbf{e}^{t\mathbf{A}^\top} \mathbf{Q} \mathbf{e}^{t\mathbf{A}} dt.$$

指数稳定保证积分收敛。对任意非零 $\mathbf{x}$, 被积函数的二次型 $\|\mathbf{Q}^{1/2} \mathbf{e}^{t\mathbf{A}} \mathbf{x}\|_2^2$ 非负, 并在 $t=0$ 严格为正, 所以 $\mathbf{P} > \mathbf{0}$ 。对被积矩阵求导并积分,

$$\mathbf{A}^\top \mathbf{P} + \mathbf{P} \mathbf{A} = \left[\mathbf{e}^{t\mathbf{A}^\top} \mathbf{Q} \mathbf{e}^{t\mathbf{A}} \right]_0^\infty = -\mathbf{Q}.$$

唯一性可由齐次方程 $\mathbf{A}^\top \mathbf{D} + \mathbf{D} \mathbf{A} = \mathbf{0}$ 沿流积分得到 $\mathbf{D} = \mathbf{0}$ 。

反过来, 若存在 $\mathbf{P}, \mathbf{Q} > \mathbf{0}$ 满足该方程, 式 (16.19) 给出 $\dot{V} = -\mathbf{x}^\top \mathbf{Q} \mathbf{x} < 0$ 。Lyapunov 判据推出原点渐近稳定, 线性系统因而要求 $\mathbf{A}$ 全部特征值实部为负。 ■

离散时间对应方程为

$$\mathbf{A}^\top \mathbf{P} \mathbf{A} - \mathbf{P} = -\mathbf{Q}.$$

它检验一步前后能量差, 与连续时间方程的导数形式不同。

定理 16.8 离散时间 Lyapunov 方程 离散线性系统 $\mathbf{x}_{k+1} = \mathbf{A} \mathbf{x}_k$ 满足 $\rho(\mathbf{A}) < 1$, 当且仅当对每个 $\mathbf{Q} > \mathbf{0}$, 存在唯一 $\mathbf{P} > \mathbf{0}$ 满足

$$\mathbf{A}^\top \mathbf{P} \mathbf{A} - \mathbf{P} = -\mathbf{Q}.$$

证明. 若 $\rho(\mathbf{A}) < 1$, 定义

$$\mathbf{P} = \sum_{j=0}^{\infty} (\mathbf{A}^{\top})^j \mathbf{Q} \mathbf{A}^j.$$

定理 16.4 及有限维范数等价性保证级数收敛。其首项为 $\mathbf{Q} > \mathbf{0}$, 其余项半正定, 所以 $\mathbf{P} > \mathbf{0}$ 。将级数左乘 $\mathbf{A}^{\top}$ 、右乘 $\mathbf{A}$ 后与原式相减, 便得到 Lyapunov 方程。若 $\mathbf{P}_1, \mathbf{P}_2$ 都是解, 令 $\mathbf{D} = \mathbf{P}_1 - \mathbf{P}_2$, 则 $\mathbf{D} = (\mathbf{A}^{\top})^k \mathbf{D} \mathbf{A}^k$; 令 $k \rightarrow \infty$ 即得 $\mathbf{D} = \mathbf{0}$ 。

反过来, 若存在 $\mathbf{P}, \mathbf{Q} > \mathbf{0}$ 满足方程, 则

$$V(\mathbf{x}_{k+1}) - V(\mathbf{x}_k) = -\mathbf{x}_k^{\top} \mathbf{Q} \mathbf{x}_k, \quad V(\mathbf{x}) = \mathbf{x}^{\top} \mathbf{P} \mathbf{x}.$$

由紧单位球上 $\mathbf{x}^{\top} \mathbf{A}^{\top} \mathbf{P} \mathbf{A} \mathbf{x} / (\mathbf{x}^{\top} \mathbf{P} \mathbf{x}) < 1$ 取得统一上界 $c < 1$, 故 $V(\mathbf{x}_k) \leq c^k V(\mathbf{x}_0)$ 。原点指数稳定, 定理 16.4 于是给出 $\rho(\mathbf{A}) < 1$ 。■

16.3.4 能量不增时要检查极限不变集

严格负的 $\dot{V}$ 迫使轨迹离开每个非平衡状态; 只有 $\dot{V} \leq 0$ 时, 轨迹却可能停留或运动在零导数集合中。要区分这两种情况, 需要描述系统长期能够留在哪些状态。集合 Ω 称为**正向不变集** (positively invariant set), 若从任意 $\mathbf{x}_0 \in \Omega$ 出发的解在所有后续存在时刻都留在 Ω 。对自治系统记正向流为 Φ_t 。集合 M 称为**不变集** (invariant set), 若对每个 $t \geq 0$ 都有 $\Phi_t(M) = M$ 。等号比正向不变所要求的 $\Phi_t(M) \subseteq M$ 更强: 它还要求 M 中的每一点都能在 M 内找到任意时长以前的前像; 等价地, 每一点都位于一条始终留在 M 中的完整轨迹上。一条正向有界轨迹 $\mathbf{x}(t)$ 的 ω **极限集** 定义为

$$\omega(\mathbf{x}_0) = \{\mathbf{z} : \text{存在 } t_j \rightarrow \infty \text{ 使 } \mathbf{x}(t_j) \rightarrow \mathbf{z}\}.$$

正向不变集约束从集合中每一点出发的整段未来; ω 极限集则记录一条轨迹在无限远时间反复接近的状态。

定理 16.9 LaSalle 不变性原理 设自治系统 $\dot{\mathbf{x}} = \mathbf{f}(\mathbf{x})$ 的向量场局部 Lipschitz, Ω 是紧的正向不变集, V 在包含 Ω 的开邻域上连续可微, 且 $\dot{V}(\mathbf{x}) = \nabla V(\mathbf{x})^{\top} \mathbf{f}(\mathbf{x}) \leq 0$ 。记 $E = \{\mathbf{x} \in \Omega : \dot{V}(\mathbf{x}) = 0\}$, 并令 M 为包含在 E 中的最大不变集。则每条从 Ω 出发的轨迹都满足

$$\text{dist}(\mathbf{x}(t), M) \longrightarrow 0.$$

证明. 紧性和正向不变性使轨迹正向预紧, 并排除有限时间逃逸, 所以 $\omega(\mathbf{x}_0)$ 非空且紧。函数 $t \mapsto V(\mathbf{x}(t))$ 单调不增并有下界, 因而收敛到某个 v_{∞} 。若 $\mathbf{z} \in \omega(\mathbf{x}_0)$, 取 $t_j \rightarrow \infty$ 使 $\mathbf{x}(t_j) \rightarrow \mathbf{z}$, 连续性给出 $V(\mathbf{z}) = v_{\infty}$ 。

还要核对这里需要的是不变，而不只是正向不变。自治流对初值连续。对任意固定 $s \geq 0$, $\mathbf{x}(t_j + s) \rightarrow \Phi_s(\mathbf{z})$, 所以 $\Phi_s(\mathbf{z}) \in \omega(\mathbf{x}_0)$, 得到 $\Phi_s(\omega(\mathbf{x}_0)) \subseteq \omega(\mathbf{x}_0)$ 。反过来, 对充分大的 j 考察 $\mathbf{x}(t_j - s)$; 紧性允许取子列使其收敛到某个 $\mathbf{w} \in \omega(\mathbf{x}_0)$, 而流的连续性给出 $\Phi_s(\mathbf{w}) = \mathbf{z}$ 。因此 $\Phi_s(\omega(\mathbf{x}_0)) = \omega(\mathbf{x}_0)$, 极限集确实是不变集。

函数 V 在 $\omega(\mathbf{x}_0)$ 上恒为 v_∞ 。从其中任一点出发的轨迹仍留在该极限集, 沿轨迹求导便有 $\dot{V} = 0$ 。于是 $\omega(\mathbf{x}_0)$ 是 E 中的不变集, 故 $\omega(\mathbf{x}_0) \subseteq M$ 。

还需把极限点结论转成整条尾轨迹的距离结论。若 $\text{dist}(\mathbf{x}(t), M)$ 不趋零, 就存在 $\varepsilon > 0$ 和 $t_j \rightarrow \infty$ 使这些距离至少为 ε 。紧性允许取收敛子列, 其极限属于 $\omega(\mathbf{x}_0) \subseteq M$, 与距离下界矛盾。■

示例 16.10 阻尼振子的零导数集合 考虑

$$\dot{q} = p, \quad \dot{p} = -q - cp, \quad c > 0,$$

并取 $V(q, p) = (q^2 + p^2)/2$ 。沿轨迹

$$\dot{V} = q\dot{q} + p\dot{p} = -cp^2 \leq 0.$$

零导数集合是整条直线 $E = \{(q, p) : p = 0\}$, 但其中 $q \neq 0$ 的点满足 $\dot{p} = -q \neq 0$, 会立刻离开 E 。因此 E 中的最大不变子集只有原点。任意能量子水平集都紧且正向不变, 定理 16.9 遂说明所有轨迹趋向原点。仅由“ $p = 0$ 时能量瞬间不变”不能得到同一结论。

16.3.5 非正规矩阵可以先放大再衰减

谱只决定渐近指数率, 不保证每一步都缩小欧氏范数。考虑离散系统

$$\mathbf{A} = \begin{bmatrix} 1/2 & K \\ 0 & 1/2 \end{bmatrix}, \quad K > 0.$$

两个特征值都等于 $1/2$, 所以 $\rho(\mathbf{A}) < 1$ 。然而

$$\mathbf{A}^k = \begin{bmatrix} 2^{-k} & kK 2^{-(k-1)} \\ 0 & 2^{-k} \end{bmatrix}.$$

从 $\mathbf{x}_0 = (0, 1)^\top$ 出发, 第一步状态为 $(K, 1/2)^\top$; 当 K 很大时, 欧氏范数立刻远大于初始范数, 随后才因 $k2^{-k} \rightarrow 0$ 而衰减。

这种现象来自矩阵非正规, 即 $\mathbf{A}^\top \mathbf{A} \neq \mathbf{A} \mathbf{A}^\top$ 。在当前例子中, $\mathbf{A} = \frac{1}{2} \mathbf{I} + \mathbf{N}$ 且 $\mathbf{N}^2 = \mathbf{0}$; $K \neq 0$ 时矩阵只有一个线性无关的特征向量, 广义特征向量链的幂零耦合产生了 $k2^{-k}$ 因子。可对角化的非正规矩阵还可能通过近乎共

线的特征向量，使不同衰减率的模态先相消、后解消，从而产生另一类瞬态放大。因此，长期谱结论不能替代有限时间增益、伪谱或合适 Lyapunov 范数的分析。

16.3.6 初值敏感与输入响应要分开

若 f 关于状态具有 Lipschitz 常数 L ，两条使用同一输入的解满足

$$\|\mathbf{x}(t) - \tilde{\mathbf{x}}(t)\| \leq e^{L(t-t_0)} \|\mathbf{x}_0 - \tilde{\mathbf{x}}_0\|.$$

这是 Gronwall 不等式给出的有限时间敏感性上界。它保证连续依赖于初值，却在 $L > 0$ 时不表示扰动衰减。

对指数稳定线性系统，若存在 $M, \alpha > 0$ 使 $\|e^{tA}\| \leq Me^{-\alpha t}$ ，则式 (16.9) 给出

$$\|\mathbf{x}(t)\| \leq Me^{-\alpha(t-t_0)} \|\mathbf{x}_0\| + M\|\mathbf{B}\| \int_{t_0}^t e^{-\alpha(t-s)} \|\mathbf{u}(s)\| ds.$$

有界输入因而产生有界状态，但状态一般不会趋零。输入、初值与模型扰动是不同来源，稳定性结论应说明控制的是哪一种。

16.4 随机状态与观测模型

16.4.1 过程噪声与观测噪声改变不同对象

恢复式 (16.1) 与 (16.2) 中的噪声。过程噪声 $\mathbf{w}_k$ 直接进入状态演化，表示模型没有显式描述的随机作用；观测噪声 $\mathbf{v}_k$ 只污染读数，不直接改变真实状态。即使二者最终都使估计不确定，它们在联合分布中的位置不同。

给定初始分布和输入序列，状态转移核为

$$K_k(\mathbf{x}, A) = \mathbb{P}(\mathbf{A}_k \mathbf{x} + \mathbf{B}_k \mathbf{u}_k + \mathbf{w}_k \in A).$$

在标准加性状态空间模型中，先假设初值、各时刻过程噪声以及各时刻观测噪声相互独立，输入序列为给定量。于是 $\mathbf{w}_k$ 在给定 $\mathbf{x}_k$ 后，与 $\sigma(\mathbf{x}_{0:k-1}, \mathbf{y}_{1:k}, \mathbf{u}_{0:k})$ 条件独立，状态过程满足条件 Markov 性质

$$\mathbb{P}(\mathbf{x}_{k+1} \in A \mid \mathbf{x}_{0:k}, \mathbf{y}_{1:k}, \mathbf{u}_{0:k}) = K_k(\mathbf{x}_k, A).$$

Markov 性质针对真实状态。观测序列自身通常不是 Markov 链，因为当前观测未必包含预测下一观测所需的全部状态信息。

与状态转移核相对，观测核

$$G_k(\mathbf{x}, B) = \mathbb{P}(\mathbf{y}_k \in B \mid \mathbf{x}_k = \mathbf{x})$$

规定给定当前状态后会看到什么。在标准状态空间模型中，给定 $\mathbf{x}_k$ 以后， $\mathbf{y}_k$ 与更早的状态、观测和噪声条件独立。若过程噪声与观测噪声相关，或者传感器还直接依赖旧状态，就必须把相关变量并入联合状态或显式修改这个条件独立结构。

记 $y_k = \sigma(\mathbf{y}_1, \dots, \mathbf{y}_k)$ 。在只观察 $\mathbf{y}$ 时，可用于预测未来的对象变成

$$\pi_k(A) = \mathbb{P}(\mathbf{x}_k \in A \mid \mathbf{y}_k), \quad (16.21)$$

即**滤波分布** (filtering distribution)。它是根据截至当前的观测对隐藏状态形成的条件分布。真实状态 $\mathbf{x}_k$ 、带噪读数 $\mathbf{y}_k$ 与条件分布 π_k 分别是潜在对象、数据和推断结果，不能用同一个“状态”含混指代。

信息不足即使没有观测噪声也可能出现。例如 $\mathbf{x}_k = (x_{1,k}, x_{2,k})^\top$ ，而传感器只返回 $y_k = x_{1,k} + x_{2,k}$ 。观测 $y_k = 1$ 不能区分 $(1, 0)^\top$ 与 $(0, 1)^\top$ ；动力学和后续观测或许能逐步区分这两个方向，但这需要额外结构。第 18 章将用可观测性和可检测性精确刻画线性系统中哪些方向可以恢复。

16.4.2 预测与校正来自两个概率核

设当前滤波分布为 π_{k-1} 。先通过状态转移核得到预测分布

$$\pi_{k|k-1}(A) = \int K_{k-1}(\mathbf{x}, A) \pi_{k-1}(d\mathbf{x}). \quad (16.22)$$

要把校正写成密度形式，还需假设存在与状态 $\mathbf{x}$ 无关的共同 σ 有限支配测度 ν_k 以及联合可测函数 g_k ，使

$$G_k(\mathbf{x}, d\mathbf{y}) = g_k(\mathbf{y} \mid \mathbf{x}) \nu_k(d\mathbf{y}).$$

观测 $\mathbf{y}_k$ 到来后，再用似然密度 $g_k(\mathbf{y}_k \mid \mathbf{x}_k)$ 重新加权：

$$\pi_k(d\mathbf{x}) = \frac{g_k(\mathbf{y}_k \mid \mathbf{x}) \pi_{k|k-1}(d\mathbf{x})}{\int g_k(\mathbf{y}_k \mid \mathbf{z}) \pi_{k|k-1}(d\mathbf{z})}. \quad (16.23)$$

这个公式适用于分母有限且严格为正的观测值。预测传播动力学不确定性，校正利用新观测改变相对权重；两步分别来自全概率公式和 Bayes 公式。

示例 16.11 两状态模型的一次预测与校正 设隐藏状态取值于 $\{0, 1\}$ ，当前滤波概率为 $\pi_0(0) = 0.7$ 、 $\pi_0(1) = 0.3$ ，转移矩阵按“当前状态为行、下一状态为列”写成

$$P = \begin{bmatrix} 0.8 & 0.2 \\ 0.1 & 0.9 \end{bmatrix}.$$

一步预测得到

$$\pi_{1|0}(1) = 0.7 \times 0.2 + 0.3 \times 0.9 = 0.41, \quad \pi_{1|0}(0) = 0.59.$$

再设观测 $y_1 \in \{0, 1\}$ 满足 $\mathbb{P}(y_1 = 1 \mid x_1 = 0) = 0.2$ 、 $\mathbb{P}(y_1 = 1 \mid x_1 = 1) = 0.8$ 。实际看到 $y_1 = 1$ 后,

$$\pi_1(1) = \frac{0.8 \times 0.41}{0.2 \times 0.59 + 0.8 \times 0.41} = \frac{164}{223} \approx 0.735.$$

预测步骤把上一时刻的不确定性穿过转移矩阵, 校正步骤才用观测似然重新分配概率。整个计算只保存 π_0 而不保存更早观测, 正是因为标准条件独立结构已经把过去信息压缩进当前滤波分布。

示例 16.12 带泄漏温度的间接观测 设房间相对环境的温差满足

$$x_{k+1} = 0.9x_k + u_k + w_k, \quad y_k = x_k + v_k.$$

即使 $v_k = 0$, 未来温差仍因 w_k 不确定; 即使 $w_k = 0$, 当前温差仍不能从带噪 y_k 精确知道。若两种噪声同时存在, 预测阶段因过程噪声扩大不确定性, 校正阶段再根据传感器精度缩小不确定性。把 y_k 直接当作 x_k 会忽略观测噪声, 只按确定递推外推又会忽略过程噪声。

16.4.3 线性高斯假设使分布闭合

为了得到解析递推, 下面采用有限时域线性高斯模型:

$$\mathbf{x}_0 \sim \mathcal{N}(\mathbf{m}_{0|0}, \mathbf{P}_{0|0}),$$

$$\mathbf{w}_k \sim \mathcal{N}(\mathbf{0}, \mathbf{\Sigma}_{w,k}),$$

$$\mathbf{v}_k \sim \mathcal{N}(\mathbf{0}, \mathbf{\Sigma}_{v,k}).$$

假设初值、全部过程噪声和全部观测噪声彼此独立, 输入与系统矩阵为给定量。允许 $\mathbf{\Sigma}_{w,k}$ 半正定, 并先假设 $\mathbf{\Sigma}_{v,k} > \mathbf{0}$, 以保证后续创新协方差可逆。

线性变换保持高斯性, 联合高斯的条件分布仍为高斯。因此只需递推条件均值与条件协方差, 便能完整表示每个滤波分布。若初值或噪声非高斯, 均值和协方差更新仍可能给出最佳线性估计, 却不再完整描述条件分布, 也不能无条件称为精确 Bayes 滤波。

16.5 预测、滤波与平滑

16.5.1 三个条件分布使用不同信息

记

$$\begin{aligned}\mathbf{m}_{k|j} &:= \mathbb{E}[\mathbf{x}_k | \mathcal{Y}_j], \\ \mathbf{P}_{k|j} &:= \text{Cov}(\mathbf{x}_k | \mathcal{Y}_j).\end{aligned}$$

一步预测使用 $\mathcal{Y}_{k-1}$ 估计 $\mathbf{x}_k$ ，滤波使用 $\mathcal{Y}_k$ 估计同一当前状态，平滑则在固定终点 $T > k$ 后使用 $\mathcal{Y}_T$ 重新估计过去状态。未来观测能够帮助平滑，因为它们包含过去状态经过动力学传播后的信息。

16.5.2 预测步骤传播均值与协方差

假设

$$\mathbf{x}_{k-1} | \mathcal{Y}_{k-1} \sim \mathcal{N}(\mathbf{m}_{k-1|k-1}, \mathbf{P}_{k-1|k-1}).$$

由状态方程和独立零均值过程噪声，

$$\mathbf{m}_{k|k-1} = \mathbf{A}_{k-1} \mathbf{m}_{k-1|k-1} + \mathbf{B}_{k-1} \mathbf{u}_{k-1}, \quad (16.24)$$

$$\mathbf{P}_{k|k-1} = \mathbf{A}_{k-1} \mathbf{P}_{k-1|k-1} \mathbf{A}_{k-1}^\top + \Sigma_{w,k-1}. \quad (16.25)$$

交叉协方差项消失的依据是 $\mathbf{w}_{k-1}$ 与 $\mathbf{x}_{k-1} | \mathcal{Y}_{k-1}$ 独立且均值为零。若过程噪声与旧状态相关，式 (16.25) 还要保留相应交叉项。

16.5.3 一次条件高斯更新给出 Kalman 滤波

给定 $\mathcal{Y}_{k-1}$ ，预测状态与新观测的联合分布为

$$\begin{bmatrix} \mathbf{x}_k \\ \mathbf{y}_k \end{bmatrix} | \mathcal{Y}_{k-1} \sim \mathcal{N} \left(\begin{bmatrix} \mathbf{m}_{k|k-1} \\ \mathbf{C}_k \mathbf{m}_{k|k-1} \end{bmatrix}, \begin{bmatrix} \mathbf{P}_{k|k-1} & \mathbf{P}_{k|k-1} \mathbf{C}_k^\top \\ \mathbf{C}_k \mathbf{P}_{k|k-1} & \mathbf{S}_k \end{bmatrix} \right), \quad (16.26)$$

其中

$$\mathbf{S}_k = \mathbf{C}_k \mathbf{P}_{k|k-1} \mathbf{C}_k^\top + \Sigma_{v,k} \quad (16.27)$$

是**创新协方差**，

$$\mathbf{r}_k = \mathbf{y}_k - \mathbf{C}_k \mathbf{m}_{k|k-1}$$

是创新，即新观测超出预测观测的部分。

由于 $\Sigma_{v,k} > \mathbf{0}$ ，有 $\mathbf{S}_k > \mathbf{0}$ 并可逆。把第 8.7 节的条件高斯公式用于联合

分布 (16.26), 得到

$$\mathbf{K}_k = \mathbf{P}_{k|k-1} \mathbf{C}_k^\top \mathbf{S}_k^{-1}, \quad (16.28)$$

$$\mathbf{m}_{k|k} = \mathbf{m}_{k|k-1} + \mathbf{K}_k \mathbf{r}_k, \quad (16.29)$$

$$\mathbf{P}_{k|k} = \mathbf{P}_{k|k-1} - \mathbf{K}_k \mathbf{S}_k \mathbf{K}_k^\top. \quad (16.30)$$

式 (16.28) 中的 $\mathbf{K}_k$ 称为 Kalman 增益。它不是手工设定的学习率, 而是预测误差与观测误差协方差共同决定的条件高斯系数³。

定理 16.13 有限时域 Kalman 滤波 在本节线性高斯初值、独立高斯噪声及 $\mathbf{S}_k$ 可逆的条件下, 递推 (16.24) 至 (16.30) 精确给出

$$\mathbf{x}_k | \mathbf{y}_k \sim \mathcal{N}(\mathbf{m}_{k|k}, \mathbf{P}_{k|k})$$

对每个有限 k 成立。

³ R. E. Kalman, *A New Approach to Linear Filtering and Prediction Problems* In *Journal of Basic Engineering*, 1960, vol. 82, no. 1, pp. 35–45

证明. 对 k 归纳。初值按假设为高斯。若 $\mathbf{x}_{k-1} | \mathbf{y}_{k-1}$ 为高斯, 线性状态方程与独立高斯过程噪声使 $\mathbf{x}_k | \mathbf{y}_{k-1}$ 仍为高斯, 其均值和协方差由 (16.24) 与 (16.25) 给出。观测又是预测状态与独立高斯噪声的线性组合, 所以联合分布为 (16.26)。条件高斯公式给出 (16.29) 与 (16.30), 完成归纳。 ■

协方差更新还可写成 Joseph 形式

$$\mathbf{P}_{k|k} = (\mathbf{I} - \mathbf{K}_k \mathbf{C}_k) \mathbf{P}_{k|k-1} (\mathbf{I} - \mathbf{K}_k \mathbf{C}_k)^\top + \mathbf{K}_k \mathbf{\Sigma}_{v,k} \mathbf{K}_k^\top. \quad (16.31)$$

代入 Kalman 增益并展开, 可化为式 (16.30)。Joseph 形式把两类误差来源都写成半正定项, 在有限精度实现中更容易维持协方差的对称与半正定。实现时也应通过线性求解获得 $\mathbf{S}_k^{-1} \mathbf{r}_k$, 而不是显式形成逆矩阵。

示例 16.14 标量观测怎样权衡预测与读数 若预测方差为 p^- , 观测为 $y = x + v$, 且 $v \sim \mathcal{N}(0, r)$, 则

$$K = \frac{p^-}{p^- + r}, \quad m^+ = m^- + K(y - m^-), \quad p^+ = \frac{p^- r}{p^- + r}.$$

当 r 很小, 增益接近 1, 更新更相信读数; 当 r 很大, 增益接近 0, 更新更相信预测。即使 $r \rightarrow 0$, 只有被直接观测的方向会被精确校正; 多维系统中未被 $\mathbf{C}_k$ 区分的方向仍可能保留不确定性。

例如 $m^- = 0$ 、 $p^- = 4$ 、 $r = 1$ 且实际读数 $y = 2$ 时,

$$K = \frac{4}{5}, \quad m^+ = \frac{8}{5}, \quad p^+ = \frac{4}{5}.$$

后验均值位于预测均值 0 与读数 2 之间，后验方差也小于预测方差和观测噪声方差；后一比较依赖两项误差独立且方差均为正。

16.5.4 RTS 平滑利用未来观测修正过去

滤波只向前传递。固定终点 T 后，Rauch-Tung-Striebel (RTS) 平滑器从 $k = T - 1$ 向后计算 $p(\mathbf{x}_k | \mathbf{y}_T)$ ⁴。关键是先求 $p(\mathbf{x}_k | \mathbf{x}_{k+1}, \mathbf{y}_k)$ 。

给定 $\mathbf{y}_k$ ，由状态方程可得联合高斯

$$\begin{bmatrix} \mathbf{x}_k \\ \mathbf{x}_{k+1} \end{bmatrix} | \mathbf{y}_k \sim \mathcal{N} \left(\begin{bmatrix} \mathbf{m}_{k|k} \\ \mathbf{m}_{k+1|k} \end{bmatrix}, \begin{bmatrix} \mathbf{P}_{k|k} & \mathbf{P}_{k|k} \mathbf{A}_k^\top \\ \mathbf{A}_k \mathbf{P}_{k|k} & \mathbf{P}_{k+1|k} \end{bmatrix} \right).$$

若 $\mathbf{P}_{k+1|k}$ 可逆，条件高斯公式给出

$$\mathbf{J}_k = \mathbf{P}_{k|k} \mathbf{A}_k^\top \mathbf{P}_{k+1|k}^{-1}, \quad (16.32)$$

$$\mathbb{E}[\mathbf{x}_k | \mathbf{x}_{k+1}, \mathbf{y}_k] = \mathbf{m}_{k|k} + \mathbf{J}_k (\mathbf{x}_{k+1} - \mathbf{m}_{k+1|k}), \quad (16.33)$$

$$\text{Cov}(\mathbf{x}_k | \mathbf{x}_{k+1}, \mathbf{y}_k) = \mathbf{P}_{k|k} - \mathbf{J}_k \mathbf{P}_{k+1|k} \mathbf{J}_k^\top. \quad (16.34)$$

⁴ H. E. Rauch, F. Tung, C. T. Striebel, *Maximum Likelihood Estimates of Linear Dynamic Systems* In AIAA Journal, 1965, vol. 3, no. 8, pp. 1445–1450

定理 16.15 有限时域 RTS 平滑 在有限时域 Kalman 滤波条件下，并假设每个 $\mathbf{P}_{k+1|k}$ 可逆，以

$$\mathbf{m}_{T|T}, \quad \mathbf{P}_{T|T}$$

为终点，向后递推

$$\mathbf{m}_{k|T} = \mathbf{m}_{k|k} + \mathbf{J}_k (\mathbf{m}_{k+1|T} - \mathbf{m}_{k+1|k}), \quad (16.35)$$

$$\mathbf{P}_{k|T} = \mathbf{P}_{k|k} + \mathbf{J}_k (\mathbf{P}_{k+1|T} - \mathbf{P}_{k+1|k}) \mathbf{J}_k^\top \quad (16.36)$$

可精确得到 $\mathbf{x}_k | \mathbf{y}_T$ 的均值与协方差。

证明. 状态的 Markov 结构与观测条件独立性给出

$$p(\mathbf{x}_k | \mathbf{x}_{k+1}, \mathbf{y}_T) = p(\mathbf{x}_k | \mathbf{x}_{k+1}, \mathbf{y}_k).$$

未来观测 $\mathbf{y}_{k+1:T}$ 在给定 $\mathbf{x}_{k+1}$ 后，不再提供关于 $\mathbf{x}_k$ 的额外信息。因此

$$p(\mathbf{x}_k | \mathbf{y}_T) = \int p(\mathbf{x}_k | \mathbf{x}_{k+1}, \mathbf{y}_k) p(\mathbf{x}_{k+1} | \mathbf{y}_T) d\mathbf{x}_{k+1}. \quad (16.37)$$

对式 (16.33) 关于 $\mathbf{x}_{k+1} | \mathbf{y}_T$ 取期望，塔式性质立即给出 (16.35)。

再使用全协方差公式。式 (16.34) 不依赖 $\mathbf{x}_{k+1}$ ，构成条件内协方差项。条

件均值关于 $\mathbf{x}_{k+1}$ 的随机部分为 $\mathbf{J}_k \mathbf{x}_{k+1}$ ，其协方差为 $\mathbf{J}_k \mathbf{P}_{k+1|T} \mathbf{J}_k^\top$ 。两项相加得到

$$\mathbf{P}_{k|T} = \mathbf{P}_{k|k} - \mathbf{J}_k \mathbf{P}_{k+1|k} \mathbf{J}_k^\top + \mathbf{J}_k \mathbf{P}_{k+1|T} \mathbf{J}_k^\top,$$

整理即为 (16.36)。从 T 向后归纳便完成证明。 ■

示例 16.16 未来观测降低过去状态的不确定性 取标量模型 $x_1 = x_0 + w_0$ 、 $y_1 = x_1 + v_1$ ，并设 $m_{0|0} = 0$ 、 $P_{0|0} = 1$ 、 $\Sigma_{w,0} = 1$ 、 $\Sigma_{v,1} = 2/3$ 。若观察到 $y_1 = 2$ ，前向预测与滤波给出

$$m_{1|0} = 0, \quad P_{1|0} = 2, \quad m_{1|1} = \frac{3}{2}, \quad P_{1|1} = \frac{1}{2}.$$

RTS 增益为 $J_0 = P_{0|0}/P_{1|0} = 1/2$ ，所以

$$m_{0|1} = \frac{3}{4}, \quad P_{0|1} = 1 + \frac{1}{4} \left(\frac{1}{2} - 2 \right) = \frac{5}{8}.$$

时刻 0 没有新观测，滤波估计仍为均值 0、方差 1；看到时刻 1 的读数后，平滑估计把过去均值移向与该读数一致的方向，并把方差从 1 降到 5/8。这说明未来证据改变的是过去状态的条件分布，而不是物理上回到过去改变状态。

若协方差奇异，可以在高斯分布的支持子空间上使用广义逆，但必须同时检查观测值是否位于相应支持内。直接把普通逆替换成伪逆而不处理支持条件，可能写出形式正确却没有对应条件分布的公式。

16.5.5 边缘最优、路径最优与近似滤波

在线性高斯模型下， $\mathbf{m}_{k|T}$ 是平方损失下估计 $\mathbf{x}_k$ 的条件均值。当边缘后验协方差正定时，它也是相对于 Lebesgue 密度的边缘众数；整条路径的后验协方差正定时，联合众数也等于联合均值，所以各时刻分量与平滑均值一致。退化高斯分布没有相对于全维 Lebesgue 测度的密度；若改用其仿射支持上的密度，均值仍可视作该意义下的众数。在非高斯模型中，每个时刻的边缘众数拼接起来不一定构成联合后验的最大概率路径。Viterbi 式路径最优与逐时刻边缘最优回答不同问题。

非线性状态模型

$$\mathbf{x}_{k+1} = \mathbf{f}_k(\mathbf{x}_k) + \mathbf{w}_k, \quad \mathbf{y}_k = \mathbf{g}_k(\mathbf{x}_k) + \mathbf{v}_k$$

一般不保持高斯闭合。扩展 Kalman 滤波在当前均值附近用 Jacobian 矩阵线性化，近似的是局部函数。无迹 Kalman 滤波选取一组确定性 sigma 点传播，再匹配变换后均值与协方差，近似的是矩传播。二者都不会把一般非高斯后验变成精确高斯。多峰、强非线性或硬约束下，粒子方法、混合

表示或问题专用推断可能更合适。

本节只给出有限时域递推。滤波增益是否收敛、极限协方差是否唯一稳定，还需要系统的可检测性、噪声作用范围等条件，这些条件将在第 18 章结合系统结构讨论。该章沿用本章的 $\mathbf{x}_k$ 、 $\mathbf{u}_k$ 、 $\mathbf{y}_k$ 作为状态、输入和输出，只把时间下标改为 t ；本章给定 $\mathbf{u}_k$ 并令 $\mathbf{y}_k = \mathbf{C}_k \mathbf{x}_k + \mathbf{v}_k$ ，该章则把 $\mathbf{u}_t$ 改为反馈选择，并允许 $\mathbf{D}\mathbf{u}_t$ 直接进入输出。

16.6 平均动力学与线性随机递推

16.6.1 平均漂移的负号决定稳定方向

第 9.4 节把随机逼近写成

$$\theta^{(k+1)} = \theta^{(k)} + \alpha_k [\bar{\mathbf{h}}(\theta^{(k)}) + \xi_{k+1} + \mathbf{r}_{k+1}].$$

对线性平均漂移，常见形式为

$$\bar{\mathbf{h}}(\theta) = \mathbf{b} - \mathbf{A}\theta. \quad (16.38)$$

若 $\mathbf{A}$ 可逆，候选平衡点为 $\theta^* = \mathbf{A}^{-1}\mathbf{b}$ 。令 $\mathbf{e} = \theta - \theta^*$ ，平均 ODE 变成

$$\dot{\mathbf{e}} = -\mathbf{A}\mathbf{e}. \quad (16.39)$$

稳定性检查的是 $-\mathbf{A}$ 是否 Hurwitz，等价于 $\mathbf{A}$ 的全部特征值实部为正。漏掉负号会把稳定与发散方向完全颠倒。

若 $\mathbf{A}$ 对称正定， $V(\mathbf{e}) = \|\mathbf{e}\|_2^2/2$ 满足

$$\dot{V} = -\mathbf{e}^\top \mathbf{A} \mathbf{e} < 0.$$

但随机逼近中的 $\mathbf{A}$ 常常不对称，也未必是某个标量目标的 Hessian 矩阵。此时不能因为更新看起来像“下降”就套用凸优化曲率。

16.6.2 对称部分给出充分条件但不是必要条件

对一般实矩阵，

$$\mathbf{e}^\top \mathbf{A} \mathbf{e} = \mathbf{e}^\top \frac{\mathbf{A} + \mathbf{A}^\top}{2} \mathbf{e},$$

因为反对称部分的二次型为零。所以若

$$\frac{\mathbf{A} + \mathbf{A}^\top}{2} > \mathbf{0}, \quad (16.40)$$

欧氏能量严格下降，从而平均 ODE 稳定。这是方便的充分条件。

它不是必要条件。例如

$$\mathbf{A} = \begin{bmatrix} 1 & 10 \\ 0 & 1 \end{bmatrix}$$

的特征值实部均为正, 所以 $-\mathbf{A}$ 稳定; 但其对称部分

$$\frac{\mathbf{A} + \mathbf{A}^\top}{2} = \begin{bmatrix} 1 & 5 \\ 5 & 1 \end{bmatrix}$$

有一个负特征值。欧氏范数可能暂时增长, 仍存在另一个二次 Lyapunov 函数证明长期稳定。

由定理 16.7, 只要 $-\mathbf{A}$ 为 Hurwitz 矩阵, 对任意 $\mathbf{Q} > \mathbf{0}$ 都存在 $\mathbf{P} > \mathbf{0}$ 满足

$$\mathbf{A}^\top \mathbf{P} + \mathbf{P} \mathbf{A} = \mathbf{Q}. \quad (16.41)$$

于是 $V(\mathbf{e}) = \mathbf{e}^\top \mathbf{P} \mathbf{e}$ 沿式 (16.39) 满足 $\dot{V} = -\mathbf{e}^\top \mathbf{Q} \mathbf{e}$ 。矩阵 $\mathbf{P}$ 选择了适合非对称漂移的加权几何。

16.6.3 平稳 Markov 算子产生一个稳定漂移

线性时序差分学习提供了一个重要例子。固定策略诱导有限状态 Markov 转移矩阵 $\mathbf{P}_\pi$, 设其平稳分布为 $\mathbf{d}$, 并令 $\mathbf{D} = \text{diag}(\mathbf{d})$ 。特征矩阵为 $\Phi \in \mathbb{R}^{n \times q}$, 折扣因子满足 $0 \leq \gamma < 1$ 。同策略线性 TD 的平均漂移可写成

$$\bar{\mathbf{h}}(\theta) = \mathbf{b} - \mathbf{A}_{\text{TD}} \theta, \quad \mathbf{A}_{\text{TD}} = \Phi^\top \mathbf{D} (\mathbf{I} - \gamma \mathbf{P}_\pi) \Phi. \quad (16.42)$$

若某些 $d_i = 0$, $\|\mathbf{z}\|_{\mathbf{D}} = (\mathbf{z}^\top \mathbf{D} \mathbf{z})^{1/2}$ 只是在全空间上的半范数。为使用通常的范数与 Cauchy-Schwarz 表述, 下文先假设所考虑的状态满足 $d_i > 0$; 更一般地, 后续严格稳定结论只需直接假设 $\Phi^\top \mathbf{D} \Phi > \mathbf{0}$ 。平稳性使 $\mathbf{P}_\pi$ 在 $\mathbf{D}$ 加权二范数下非扩张。对任意向量 $\mathbf{z}$, Jensen 不等式给出

$$(\mathbf{P}_\pi \mathbf{z})_i^2 \leq \sum_j (\mathbf{P}_\pi)_{i,j} z_j^2.$$

乘以 d_i 并求和, 再用 $\sum_i d_i (\mathbf{P}_\pi)_{i,j} = d_j$, 得到

$$\|\mathbf{P}_\pi \mathbf{z}\|_{\mathbf{D}} \leq \|\mathbf{z}\|_{\mathbf{D}}. \quad (16.43)$$

因此由 Cauchy-Schwarz 不等式,

$$\langle \mathbf{z}, \mathbf{P}_\pi \mathbf{z} \rangle_{\mathbf{D}} \leq \|\mathbf{z}\|_{\mathbf{D}} \|\mathbf{P}_\pi \mathbf{z}\|_{\mathbf{D}} \leq \|\mathbf{z}\|_{\mathbf{D}}^2.$$

令 $\mathbf{z} = \Phi \mathbf{c}$, 可得

$$\begin{aligned} \mathbf{c}^\top \mathbf{A}_{\text{TD}} \mathbf{c} &= \|\Phi \mathbf{c}\|_D^2 - \gamma \langle \Phi \mathbf{c}, \mathbf{P}_\pi \Phi \mathbf{c} \rangle_D \\ &\geq (1 - \gamma) \|\Phi \mathbf{c}\|_D^2. \end{aligned} \quad (16.44)$$

若特征协方差 $\Phi^\top D \Phi > \mathbf{0}$, 则右侧对 $\mathbf{c} \neq \mathbf{0}$ 严格为正。因此 $\mathbf{A}_{\text{TD}}$ 的对称部分正定, 平均 ODE 具有唯一全局指数稳定平衡。

这个证明使用了固定策略下的平稳权重、 $\gamma < 1$ 和加权特征协方差正定。在所有 $d_i > 0$ 的假设下, 最后一个条件等价于 Φ 满列秩; 若允许零平稳质量, 普通满列秩并不足够。离策略采样把 D 换成另一访问分布, 而转移算子仍来自目标策略, 式 (16.43) 可能不再成立。所以同策略稳定不能直接推出离策略稳定。

16.6.4 平均 ODE 稳定还不是随机递推收敛

平均 ODE 只描述噪声抵消后的方向。要把稳定平衡转成 $\theta^{(k)} \rightarrow \theta^*$, 仍需核对第 9.4 节的条件:

$$\sum_k \alpha_k = \infty, \quad \sum_k \alpha_k^2 < \infty,$$

加权噪声在有限算法时间窗内消失, 偏差项可控, 并且迭代几乎必然有界。Markov 采样还需要 Poisson 方程或相应混合条件, 不能只用平稳平均替代相关噪声分析。

标量线性递推可以直接显示这些条件怎样配合。设

$$\theta^{(k+1)} = \theta^{(k)} + \alpha_k [b - a\theta^{(k)} + \xi_{k+1}], \quad a > 0,$$

其中 $\mathbb{E}[\xi_{k+1} | \mathcal{F}_k] = 0$ 且 $\mathbb{E}[\xi_{k+1}^2 | \mathcal{F}_k] \leq \sigma^2$ 。令 $e_k = \theta^{(k)} - b/a$, 条件二阶矩满足

$$\mathbb{E}[e_{k+1}^2 | \mathcal{F}_k] = (1 - a\alpha_k)^2 e_k^2 + \alpha_k^2 \mathbb{E}[\xi_{k+1}^2 | \mathcal{F}_k].$$

当步长最终足够小, 第一项提供与 $\alpha_k e_k^2$ 同阶的收缩; $\sum_k \alpha_k^2 < \infty$ 又使累计噪声能量有限。结合 $\sum_k \alpha_k = \infty$, 第 9.4 节的超鞅收敛论证可推出 $e_k \rightarrow 0$ 几乎必然。若噪声有系统偏差、条件方差失控或迭代不能保持有界, 平均 ODE 的稳定性本身不能补上这些缺口。

双时间尺度递推进一步要求 $\alpha_k/\beta_k \rightarrow 0$, 使快变量在慢变量近似冻结时接近稳定平衡映射。这个步长比只建立时间尺度分离。固定慢变量时的快 ODE、代入平衡映射后的慢 ODE、联合噪声与联合有界性都要分别验证。平均漂移稳定是收敛证明的一环, 不是整份证明。

例如考虑

$$\begin{aligned} y^{(k+1)} &= y^{(k)} + \beta_k [x^{(k)} - y^{(k)} + \eta_{k+1}], \\ x^{(k+1)} &= x^{(k)} + \alpha_k [c - x^{(k)} - y^{(k)} + \xi_{k+1}], \end{aligned}$$

并令 $\alpha_k/\beta_k \rightarrow 0$ 。冻结 x 时，快 ODE $\dot{y} = x - y$ 具有稳定根 $y^*(x) = x$ ；将它代入慢更新，得到 $\dot{x} = c - 2x$ ，其稳定根为 $x^* = c/2$ 。因此候选联合极限为 $(x^*, y^*) = (c/2, c/2)$ 。这个代入只分析平均场；要把候选极限变成随机递推结论，仍需两组步长各自满足随机逼近条件、噪声满足相应鞅差或混合假设，并证明联合迭代有界。

16.7 连续时间噪声与布朗运动

16.7.1 随机游走的连续极限具有平方根尺度

设 $\xi_1, \xi_2, \dots$ 独立同分布， $\mathbb{E}\xi_i = 0$ 、 $\text{Var}(\xi_i) = 1$ 。步长为 Δt 时，定义随机游走增量

$$\Delta X_k = \sqrt{\Delta t} \xi_k.$$

经过 $n = t/\Delta t$ 步，

$$\text{Var}\left(\sum_{k=1}^n \Delta X_k\right) = n\Delta t = t.$$

若把增量缩放成 $\Delta t \xi_k$ ，方差会随 $\Delta t \rightarrow 0$ 趋零；若不缩放，固定时间内方差会发散。平方根尺度是让连续时间极限保留有限非零波动的尺度。

在有限方差及适当插值条件下，函数型中心极限定理把缩放随机游走连接到布朗运动。本章不重证该一般弱收敛定理，而从极限所需的性质定义连续对象。

定义 16.17 标准布朗运动 实值过程 $(W_t)_{t \geq 0}$ 称为标准布朗运动，若它满足：

1. $W_0 = 0$ 几乎必然成立；
2. 对 $0 \leq t_0 < t_1 < \dots < t_n$ ，增量 $W_{t_i} - W_{t_{i-1}}$ 相互独立；
3. $W_t - W_s \sim \mathcal{N}(0, t - s)$ ，其中 $0 \leq s < t$ ；
4. 样本路径几乎必然连续。

当布朗运动与滤过 $(\mathcal{F}_t)_{t \geq 0}$ 共同使用时，还要求 W_t 对该滤过适应，并且对 $s < t$ ，增量 $W_t - W_s$ 独立于 $\mathcal{F}_s$ 。定义中的独立增量只比较布朗运动自身的不同时间段；加入滤过后的条件保证积分中的“过去信息”不能预见下一段布朗增量。

由独立增量和方差公式,

$$\mathbb{E}[W_s W_t] = \min(s, t). \quad (16.45)$$

例如 $s \leq t$ 时, $W_t = W_s + (W_t - W_s)$, 后一增量与 W_s 独立且均值为零, 所以协方差为 $\mathbb{E}W_s^2 = s$ 。

16.7.2 尺度不变性不等于路径可微

对任意 $c > 0$, 过程

$$\widetilde{W}_t = c^{-1/2} W_{ct}$$

仍是标准布朗运动。它从零出发, 增量仍独立, 并且

$$\widetilde{W}_t - \widetilde{W}_s \sim \mathcal{N}(0, t - s).$$

连续性也由原路径继承。因此两过程具有相同的有限维分布。这就是布朗运动的尺度规律。

长度为 h 的增量典型大小为 $\sqrt{h}$, 所以差商

$$\frac{W_{t+h} - W_t}{h}$$

的标准差为 $1/\sqrt{h}$, 随 $h \rightarrow 0$ 反而发散。严格结果表明, 以概率 1, 布朗运动的样本路径在所有时刻连续, 同时在任何时刻都不可微。因此不能把 dW_t/dt 当作普通随机函数, 再用 Riemann 积分处理。

16.7.3 二次变差留下有限极限

取 $[0, t]$ 的分割 $0 = t_0 < t_1 < \dots < t_n = t$, 网格大小趋零。定义平方增量和

$$Q_n = \sum_{i=0}^{n-1} (W_{t_{i+1}} - W_{t_i})^2.$$

其期望为

$$\mathbb{E}Q_n = \sum_i (t_{i+1} - t_i) = t.$$

独立高斯增量还给出

$$\text{Var}(Q_n) = 2 \sum_i (t_{i+1} - t_i)^2 \leq 2t \max_i (t_{i+1} - t_i).$$

因此网格趋零时, $Q_n \rightarrow t$ 在 L^2 中成立, 进而依概率成立。这称为布朗运动在 $[0, t]$ 上的二次变差等于 t 。

普通连续可微路径的平方增量和会趋零, 因为每个增量是 $O(\Delta t)$, 平方

后求和为 $O(\Delta t)$ 。布朗增量是 $O_{\mathbb{P}}(\sqrt{\Delta t})$ ，平方后恰好是 $O_{\mathbb{P}}(\Delta t)$ 。下一节的 Itô 公式之所以保留二阶导数项，根源就在这个非零二次变差。

16.8 随机微分与密度演化

16.8.1 Itô 积分要求被积过程不能预见未来

先对可预测简单过程定义积分。给定分割 $0 = t_0 < \cdots < t_n = T$ ，令

$$H_t = \sum_{i=0}^{n-1} H_i \mathbb{1}_{(t_i, t_{i+1}]}(t),$$

其中 H_i 对 $\mathcal{F}_{t_i}$ 可测且平方可积。定义

$$\int_0^T H_t dW_t := \sum_{i=0}^{n-1} H_i (W_{t_{i+1}} - W_{t_i}). \quad (16.46)$$

左端点可测性表示 H_i 可以依赖过去，却不能利用尚未发生的布朗增量。

令

$$M_t = \int_0^t H_s dW_s = \sum_{i=0}^{n-1} H_i (W_{t \wedge t_{i+1}} - W_{t \wedge t_i}).$$

这个过程对 $\mathcal{F}_t$ 适应且平方可积。对 $0 \leq s < t \leq T$ ，把 $M_t - M_s$ 按分割区间展开。对包含 s 的区间，系数已经对 $\mathcal{F}_s$ 可测，而 s 之后的增量独立于 $\mathcal{F}_s$ ；对每个起点 $t_i \geq s$ 的完整区间，塔式性质给出

$$\mathbb{E}[H_i \Delta W_i \mid \mathcal{F}_s] = \mathbb{E}[\mathbb{E}[H_i \Delta W_i \mid \mathcal{F}_{t_i}] \mid \mathcal{F}_s] = 0.$$

因此

$$\mathbb{E}[M_t - M_s \mid \mathcal{F}_s] = 0, \quad \mathbb{E}[M_t \mid \mathcal{F}_s] = M_s.$$

所以 $(M_t)_{0 \leq t \leq T}$ 是平方可积鞅，特别地 $\mathbb{E}[M_T] = 0$ 。

等距关系还需要核对平方展开中的交叉项。记 $\Delta W_i = W_{t_{i+1}} - W_{t_i}$ 。当 $i < j$ 时， $H_i H_j \Delta W_i$ 对 $\mathcal{F}_{t_j}$ 可测，故

$$\mathbb{E}[H_i H_j \Delta W_i \Delta W_j] = \mathbb{E}[H_i H_j \Delta W_i \mathbb{E}[\Delta W_j \mid \mathcal{F}_{t_j}]] = 0.$$

对角项则由 ΔW_i 独立于 $\mathcal{F}_{t_i}$ 及其方差 $t_{i+1} - t_i$ 得到

$$\mathbb{E}[H_i^2 (\Delta W_i)^2] = \mathbb{E}[H_i^2] (t_{i+1} - t_i).$$

将各项相加，得到**Itô 等距** (Itô isometry)

$$\mathbb{E} \left[\left(\int_0^T H_t dW_t \right)^2 \right] = \mathbb{E} \int_0^T H_t^2 dt. \quad (16.47)$$

对可预测过程 H ，若满足 $\mathbb{E} \int_0^T H_t^2 dt < \infty$ ，便可用可预测简单过程在该二阶范数下逼近，并借助等距关系把积分连续延拓。条件期望是 L^2 压缩映射，因此上述鞅等式也在这个极限下保留： $M_t = \int_0^t H_s dW_s$ 仍是平方可积鞅。也可以从渐进可测且满足同一平方可积条件的过程出发；在通常滤过条件下，可取与它在 $\mathbb{P} \otimes dt$ 意义下等价的可预测版本，因而得到相同的积分对象。仅有适应性并不足以保证上述逼近与积分定义成立。

若使用右端点或中点，被积量会含有当前增量的信息，极限一般不同。Stratonovich 积分采用对称极限并保留普通链式法则，Itô 积分采用左端适应性并产生二次变差修正。两种约定都合法，但模型漂移在二者转换时会改变，不能只换积分符号⁵。

⁵ B. Øksendal, *Stochastic Differential Equations: An Introduction with Applications*, Springer, 2003, 6th ed.

16.8.2 随机微分方程是积分方程

先明确多维驱动对象。相对于同一滤过， m 维标准布朗运动 $\mathbf{W}_t = (W_t^{(1)}, \dots, W_t^{(m)})^\top$ 由相互独立的实值标准布朗运动组成。对 $0 \leq s < t$ ，增量 $\mathbf{W}_t - \mathbf{W}_s$ 独立于 $\mathcal{F}_s$ ，并满足

$$\mathbf{W}_t - \mathbf{W}_s \sim \mathcal{N}(\mathbf{0}, (t-s)\mathbf{I}_m), \quad [W^{(i)}, W^{(j)}]_t = \delta_{i,j}t.$$

最后一个等式说明不同分量的交叉二次变差为零，而每个分量的二次变差为 t 。

d 维状态由这个 m 维布朗运动驱动时，Itô 随机微分方程 (stochastic differential equation, SDE) 写成

$$d\mathbf{X}_t = \mathbf{b}(t, \mathbf{X}_t) dt + \boldsymbol{\sigma}(t, \mathbf{X}_t) d\mathbf{W}_t. \quad (16.48)$$

其中 $\mathbf{b} : [0, T] \times \mathbb{R}^d \rightarrow \mathbb{R}^d$ 是漂移， $\boldsymbol{\sigma} : [0, T] \times \mathbb{R}^d \rightarrow \mathbb{R}^{d \times m}$ 是扩散系数。它的含义是

$$\mathbf{X}_t = \mathbf{X}_0 + \int_0^t \mathbf{b}(s, \mathbf{X}_s) ds + \int_0^t \boldsymbol{\sigma}(s, \mathbf{X}_s) d\mathbf{W}_s.$$

在给定的滤过概率空间、初值和布朗运动上，若一个 $\mathcal{F}_t$ 适应的连续过程使两个积分都有定义，并且上式以概率 1 对所有 $t \in [0, T]$ 同时成立，就称它为该方程的**强解** (strong solution)。这里的“强”强调解使用给定的布朗运动，而不只指定解的分布；路径唯一性是指同一空间上使用同一初值和布朗运动的两个强解几乎必然处处相同。

定理 16.18 SDE 强解的存在唯一性 设 $(\mathcal{F}_t)_{t \geq 0}$ 满足通常条件，即完备且右连续， $\mathbf{W}$ 是相对于该滤过的 m 维标准布朗运动， $\mathbf{X}_0$ 对 $\mathcal{F}_0$ 可测且 $\mathbb{E} \|\mathbf{X}_0\|_2^2 < \infty$ 。设 $\mathbf{b}$ 与 $\boldsymbol{\sigma}$ 关于 $(t, \mathbf{x})$ 联合 Borel 可测。若存在常

数 L, C , 使对所有 $t \in [0, T]$ 及 $\mathbf{x}, \mathbf{y} \in \mathbb{R}^d$,

$$\begin{aligned}\|\mathbf{b}(t, \mathbf{x}) - \mathbf{b}(t, \mathbf{y})\|_2 + \|\boldsymbol{\sigma}(t, \mathbf{x}) - \boldsymbol{\sigma}(t, \mathbf{y})\|_F &\leq L\|\mathbf{x} - \mathbf{y}\|_2, \\ \|\mathbf{b}(t, \mathbf{x})\|_2^2 + \|\boldsymbol{\sigma}(t, \mathbf{x})\|_F^2 &\leq C(1 + \|\mathbf{x}\|_2^2),\end{aligned}$$

则式 (16.48) 在 $[0, T]$ 上存在唯一强解, 并且 $\mathbb{E} \sup_{t \leq T} \|\mathbf{X}_t\|_2^2 < \infty$ 。

证明仍采用 Picard 迭代, 但确定性积分的上界要与 Itô 等距和鞅最大不等式配合。在足够短的时间区间上, 这些估计使迭代成为二阶过程空间中的压缩; 逐段延拓覆盖 $[0, T]$ 。对两组解作差并使用同样估计, 再由 Grönwall 不等式得到路径唯一性。线性增长界控制二阶矩并排除有限时间爆炸。若只有局部 Lipschitz, 以上论证先给出爆炸时刻之前的局部唯一解, 还需额外增长或 Lyapunov 条件证明爆炸时刻几乎必然大于 T 。

16.8.3 Itô 公式保留 Taylor 二阶项

定理 16.19 Itô 公式 设 $\mathbf{X}_t$ 满足式 (16.48), 并令 $f(t, \mathbf{x})$ 关于 t 一阶连续可微、关于 $\mathbf{x}$ 二阶连续可微。在相应可积条件下,

$$\begin{aligned}df(t, \mathbf{X}_t) &= \left[\partial_t f + \nabla f^\top \mathbf{b} + \frac{1}{2} \text{tr}(\boldsymbol{\sigma} \boldsymbol{\sigma}^\top \nabla^2 f) \right] dt \\ &\quad + \nabla f^\top \boldsymbol{\sigma} d\mathbf{W}_t,\end{aligned}\tag{16.49}$$

其中右侧各函数在 $(t, \mathbf{X}_t)$ 处取值。

证明路线与关键项。 先在分割上对 $f(t_{i+1}, \mathbf{X}_{t_{i+1}}) - f(t_i, \mathbf{X}_{t_i})$ 作二阶 Taylor 展开。状态增量为

$$\Delta \mathbf{X}_i = \mathbf{b}_i \Delta t_i + \boldsymbol{\sigma}_i \Delta \mathbf{W}_i + \text{高阶余项}.$$

一阶项产生 $\partial_t f \Delta t_i$ 、 $\nabla f^\top \mathbf{b}_i \Delta t_i$ 和 $\nabla f^\top \boldsymbol{\sigma}_i \Delta \mathbf{W}_i$ 。二阶项中, $(\Delta t_i)^2$ 及 $\Delta t_i \Delta \mathbf{W}_i$ 求和后消失; 而 $\Delta \mathbf{W}_i \Delta \mathbf{W}_i^\top$ 的和依二次变差趋向 $\mathbf{I} \Delta t_i$ 。因此留下

$$\frac{1}{2} \text{tr}(\boldsymbol{\sigma} \boldsymbol{\sigma}^\top \nabla^2 f) \Delta t_i.$$

完整证明还需先用停时把 $\mathbf{X}$ 、系数及 f 的导数局部化到有界区域, 再以简单可预测过程逼近随机被积项, 并分别证明 Taylor 余项、漂移和二次变差交叉项在相应概率或 L^1 意义下收敛; 最后令停时趋向无穷。这里给出的展开只说明二阶修正项的来源, 不替代这些局部化、逼近与收敛论证。

形式记忆规则

$$(dW_t)^2 = dt, \quad dW_t dt = 0, \quad (dt)^2 = 0$$

概括了量级，但不能替代适应性、可积性与极限证明。

两个基本例子可以核对积分约定。常数被积过程给出 $\int_0^T c dW_t = cW_T$ 。对 $f(x) = x^2$ 应用 Itô 公式则有

$$W_T^2 = 2 \int_0^T W_t dW_t + T, \quad \int_0^T W_t dW_t = \frac{W_T^2 - T}{2}.$$

若误用普通链式法则，就会漏掉由二次变差产生的 $-T/2$ 修正。

16.8.4 线性 SDE 的均值与协方差可以直接核对

先考虑确定性系数的向量线性 SDE

$$d\mathbf{X}_t = (\mathbf{A}_t \mathbf{X}_t + \mathbf{c}_t) dt + \mathbf{G}_t d\mathbf{W}_t,$$

其中 $\mathbf{A}_t \in \mathbb{R}^{d \times d}$ 和 $\mathbf{c}_t \in \mathbb{R}^d$ 是确定性的局部可积函数， $\mathbf{G}_t \in \mathbb{R}^{d \times m}$ 是确定性函数且 $\|\mathbf{G}_t\|_F^2$ 局部可积，并假设 $\mathbf{X}_0 \in L^2$ 。这些条件保证方程有唯一平方可积强解；相应的均值与协方差函数绝对连续，下面的微分方程对几乎处处的 t 成立。记

$$\mathbf{m}_t = \mathbb{E}[\mathbf{X}_t], \quad \mathbf{P}_t = \text{Cov}(\mathbf{X}_t).$$

对积分方程取期望，随机积分的鞅性质给出

$$\dot{\mathbf{m}}_t = \mathbf{A}_t \mathbf{m}_t + \mathbf{c}_t. \quad (16.50)$$

再令 $\tilde{\mathbf{X}}_t = \mathbf{X}_t - \mathbf{m}_t$ ，则 $d\tilde{\mathbf{X}}_t = \mathbf{A}_t \tilde{\mathbf{X}}_t dt + \mathbf{G}_t d\mathbf{W}_t$ 。对矩阵乘积使用 Itô 公式，

$$\begin{aligned} d(\tilde{\mathbf{X}}_t \tilde{\mathbf{X}}_t^\top) &= \left(\mathbf{A}_t \tilde{\mathbf{X}}_t \tilde{\mathbf{X}}_t^\top + \tilde{\mathbf{X}}_t \tilde{\mathbf{X}}_t^\top \mathbf{A}_t^\top + \mathbf{G}_t \mathbf{G}_t^\top \right) dt \\ &\quad + \mathbf{G}_t d\mathbf{W}_t \tilde{\mathbf{X}}_t^\top + \tilde{\mathbf{X}}_t d\mathbf{W}_t^\top \mathbf{G}_t^\top. \end{aligned}$$

取期望后两个随机积分项消失，得到

$$\dot{\mathbf{P}}_t = \mathbf{A}_t \mathbf{P}_t + \mathbf{P}_t \mathbf{A}_t^\top + \mathbf{G}_t \mathbf{G}_t^\top. \quad (16.51)$$

这两式说明，漂移传播已有均值与协方差，扩散项则持续注入协方差；它们是离散 Kalman 预测公式在连续时间中的对应关系。

标量 Ornstein–Uhlenbeck 过程是上述方程取 $\mathbf{A}_t = -\lambda$ 、 $\mathbf{c}_t = 0$ 和 $\mathbf{G}_t = \sigma$

的特例:

$$dX_t = -\lambda X_t dt + \sigma dW_t, \quad \lambda > 0. \quad (16.52)$$

对 $e^{\lambda t} X_t$ 使用 Itô 公式, 交叉二次变差项因确定性因子有限变差而为零, 得到

$$X_t = e^{-\lambda t} X_0 + \sigma \int_0^t e^{-\lambda(t-s)} dW_s.$$

若 X_0 与布朗运动独立,

$$\mathbb{E}X_t = e^{-\lambda t} \mathbb{E}X_0, \quad (16.53)$$

$$\text{Var}(X_t) = e^{-2\lambda t} \text{Var}(X_0) + \frac{\sigma^2}{2\lambda} (1 - e^{-2\lambda t}). \quad (16.54)$$

第二式由 Itô 等距得到。均值衰减到零, 方差却趋向 $\sigma^2/(2\lambda)$ 。随机稳定状态不是所有轨迹收敛到零, 而是阻尼与持续噪声形成平稳分布。当 $\sigma \neq 0$ 时, 该分布为非退化的 $\mathcal{N}(0, \sigma^2/(2\lambda))$; 当 $\sigma = 0$ 时, 它退化为 δ_0 。

也可对 $f(x) = x^2$ 用 Itô 公式:

$$d(X_t^2) = (-2\lambda X_t^2 + \sigma^2) dt + 2\sigma X_t dW_t.$$

取期望后随机积分均值为零, 得到二阶矩 ODE, 其解与式 (16.54) 一致。若漏掉 Itô 修正 $\sigma^2 dt$, 便会错误地预测方差也衰减到零。

16.8.5 Fokker-Planck 方程描述边缘密度

设 $\mathbf{a} = \sigma\sigma^\top$ 。对光滑紧支撑测试函数 φ , 定义时刻 t 的生成元

$$(\mathcal{L}_t \varphi)(\mathbf{x}) = \mathbf{b}(t, \mathbf{x})^\top \nabla \varphi(\mathbf{x}) + \frac{1}{2} \text{tr}(\mathbf{a}(t, \mathbf{x}) \nabla^2 \varphi(\mathbf{x})).$$

在 Itô 公式中的随机积分可积且均值为零时, 取期望得到弱演化式

$$\frac{d}{dt} \mathbb{E}[\varphi(\mathbf{X}_t)] = \mathbb{E}[(\mathcal{L}_t \varphi)(\mathbf{X}_t)].$$

这个等式只描述分布对测试函数的作用, 不预设 $\mathbf{X}_t$ 具有处处光滑的密度。

若 $\mathbf{X}_t$ 进一步具有密度 $p(t, \mathbf{x})$, 且系数与密度足够正则, 便可把弱式写成密度积分并对空间变量分部积分。边界项在测试函数紧支撑, 或密度与通量适当衰减的条件下消失, 得到

$$\partial_t p(t, \mathbf{x}) = - \sum_i \partial_{x_i} (b_i(t, \mathbf{x}) p(t, \mathbf{x})) + \frac{1}{2} \sum_{i,j} \partial_{x_i} \partial_{x_j} (a_{i,j}(t, \mathbf{x}) p(t, \mathbf{x})). \quad (16.55)$$

这就是 **Fokker-Planck 方程**。它是 SDE 生成元的伴随方程, 描述各时刻边缘密度怎样流动和扩散。

推导先在弱意义下成立。要把它解释为逐点经典偏微分方程, 还需密度

存在、系数正则性与边界条件。退化扩散矩阵可能使密度集中在低维集合，此时相对于全维 Lebesgue 测度的光滑密度未必存在。

16.8.6 数值离散、Langevin 与概率流服务于不同目标

Euler-Maruyama 方法把式 (16.48) 离散为

$$\mathbf{X}_{k+1} = \mathbf{X}_k + \mathbf{b}(t_k, \mathbf{X}_k)h + \boldsymbol{\sigma}(t_k, \mathbf{X}_k)\sqrt{h}\boldsymbol{\varepsilon}_k, \quad \boldsymbol{\varepsilon}_k \sim \mathcal{N}(\mathbf{0}, \mathbf{I}). \quad (16.56)$$

对自治系数，若 $\mathbf{b}$ 与 $\boldsymbol{\sigma}$ 全局 Lipschitz 并满足线性增长条件，且初值平方可积，则在固定有限时域的网格点上有代表性的强误差界

$$\max_{0 \leq k \leq T/h} (\mathbb{E} \|\mathbf{X}_{t_k} - \mathbf{X}_k\|_2^2)^{1/2} \leq C_T h^{1/2}.$$

若系数还显式依赖时间，需要相应的时间正则性。一个便于陈述的弱一阶充分条件是：自治的漂移、扩散系数和测试函数 φ 具有至四阶连续有界导数，并满足所需矩条件。此时

$$|\mathbb{E}\varphi(\mathbf{X}_T) - \mathbb{E}\varphi(\mathbf{X}_{T/h})| \leq C_{\varphi,T}h.$$

强误差比较同一布朗路径上的数值解与真解，弱误差比较测试函数期望；两者的对象不同，弱阶更高不表示逐路径更准确。加性噪声或更强结构可以提高特定方法的阶，但不能把这些特殊结论当作一般乘性噪声的保证。

过阻尼 Langevin SDE

$$d\mathbf{X}_t = \frac{1}{2} \nabla \log \pi(\mathbf{X}_t) dt + d\mathbf{W}_t \quad (16.57)$$

在 π 光滑、可归一化且边界通量消失等条件下，把 $p = \pi$ 代入 Fokker-Planck 方程可见漂移通量与扩散通量相消，所以 π 是不变密度。这只证明保持性。从任意初值收敛到 π 还需要遍历性与约束势能等条件，离散后的未校正 Langevin 算法还会产生步长偏差。

扩散生成模型设计随时间加噪的前向 SDE，再学习与边缘分数 $\nabla \log p_t$ 有关的反向动态。与同一边缘密度族对应的概率流 ODE 可以写成

$$\frac{d\mathbf{X}_t}{dt} = \mathbf{b}(t, \mathbf{X}_t) - \frac{1}{2} \mathbf{a}(t) \nabla \log p_t(\mathbf{X}_t)$$

这一简式要求扩散矩阵只依赖时间；状态依赖扩散还会出现额外散度项。概率流 ODE 匹配边缘密度演化，不表示它与 SDE 具有相同样本路径。反向生成还需要分数估计与时间反演条件，不能只凭前向 Fokker-Planck 方程自动得到。

16.9 Hamilton 动力学与几何积分

16.9.1 位置与动量共同组成相空间状态

前面主要问扰动是否衰减。保守系统关心另一类结构：动态可以长期移动，却保持总能量和相空间体积。令位置 $\mathbf{q} \in \mathbb{R}^d$ 、动量 $\mathbf{p} \in \mathbb{R}^d$ ，Hamilton 量为

$$H(\mathbf{q}, \mathbf{p}) = U(\mathbf{q}) + \frac{1}{2} \mathbf{p}^\top \mathbf{M}^{-1} \mathbf{p}, \quad \mathbf{M} > \mathbf{0}. \quad (16.58)$$

Hamilton 方程为

$$\dot{\mathbf{q}} = \nabla_{\mathbf{p}} H, \quad \dot{\mathbf{p}} = -\nabla_{\mathbf{q}} H. \quad (16.59)$$

第一式把动量变成位置速度，第二式让势能梯度改变动量。这不是沿 $-\nabla H$ 下降，而是用辛矩阵

$$\mathbf{J} = \begin{bmatrix} \mathbf{0} & \mathbf{I} \\ -\mathbf{I} & \mathbf{0} \end{bmatrix}$$

旋转 Hamilton 梯度。

16.9.2 精确流保持能量

定理 16.20 Hamilton 能量守恒 若 H 连续可微、不显含时间，且 Hamilton 方程的解在所考察区间存在，则沿精确轨迹

$$H(\mathbf{q}(t), \mathbf{p}(t)) = H(\mathbf{q}(0), \mathbf{p}(0)).$$

证明. 沿轨迹使用链式法则，

$$\begin{aligned} \frac{d}{dt} H &= \nabla_{\mathbf{q}} H^\top \dot{\mathbf{q}} + \nabla_{\mathbf{p}} H^\top \dot{\mathbf{p}} \\ &= \nabla_{\mathbf{q}} H^\top \nabla_{\mathbf{p}} H - \nabla_{\mathbf{p}} H^\top \nabla_{\mathbf{q}} H = 0. \end{aligned}$$

因此 Hamilton 量沿每条存在的轨迹保持常数。 ■

若 H 显式依赖时间，同一计算只给出 $dH/dt = \partial H/\partial t$ 。若解在有限时间爆炸，守恒结论也只适用于流存在的区间。能量守恒不表示位置有界；若势能的等能面不紧，轨迹仍可能逃向无穷远。

16.9.3 精确流保持相空间体积与辛形式

把 $\mathbf{z} = (\mathbf{q}, \mathbf{p})$ ，向量场写成 $\mathbf{F}(\mathbf{z}) = \mathbf{J} \nabla H(\mathbf{z})$ 。若 H 二阶连续可微，

$$\nabla \cdot \mathbf{F} = \text{tr}(\mathbf{J} \nabla^2 H) = 0,$$

因为 $\mathbf{J}$ 反对称而 $\nabla^2 H$ 对称，二者乘积的迹为零。

设流映射为 φ_t , 其 Jacobian 矩阵为 $G_t = \nabla \varphi_t(\mathbf{z}_0)$ 。变分方程给出

$$\dot{G}_t = \nabla F(\mathbf{z}(t))G_t.$$

Jacobi 行列式公式于是给出

$$\frac{d}{dt} \log |\det G_t| = \text{tr}(\nabla F) = \nabla \cdot \mathbf{F} = 0.$$

由于 $G_0 = I$, 有 $|\det G_t| = 1$ 。因此精确 Hamilton 流保持相空间体积。

体积只记录所有方向伸缩率的乘积, Hamilton 系统还保持方向对之间的几何关系。对切向量 $\mathbf{u}, \mathbf{v} \in \mathbb{R}^{2d}$, 定义**辛形式** (symplectic form)

$$\omega(\mathbf{u}, \mathbf{v}) = \mathbf{u}^\top \mathbf{J} \mathbf{v}.$$

可微映射 ψ 称为辛映射, 如果其 Jacobian 矩阵 $G = \nabla \psi$ 满足

$$G^\top \mathbf{J} G = \mathbf{J}. \quad (16.60)$$

该等式表示映射前后的任意两方向具有相同辛形式值。

若 $H \in C^2$, 沿精确流有 $\nabla F = \mathbf{J} \nabla^2 H$ 。记 $\mathbf{S} = \nabla^2 H = \mathbf{S}^\top$, 则

$$\begin{aligned} \frac{d}{dt} (G_t^\top \mathbf{J} G_t) &= G_t^\top [(\mathbf{J} \mathbf{S})^\top \mathbf{J} + \mathbf{J} (\mathbf{J} \mathbf{S})] G_t \\ &= G_t^\top (\mathbf{S} - \mathbf{S}) G_t = \mathbf{0}. \end{aligned}$$

初值为 $G_0^\top \mathbf{J} G_0 = \mathbf{J}$, 所以精确流满足式 (16.60)。对该式取行列式可得 $(\det G_t)^2 = 1$; 由 $\det G_0 = 1$ 和连续性知 $\det G_t = 1$ 。因此辛性蕴含定向体积保持, 但一般的体积保持映射未必保持辛形式。

16.9.4 蛙跳积分分别近似两个可解子流

对可分 Hamilton 量 (16.58), 一步步长为 h 的蛙跳积分写成

$$\mathbf{p}_{k+1/2} = \mathbf{p}_k - \frac{h}{2} \nabla U(\mathbf{q}_k), \quad (16.61)$$

$$\mathbf{q}_{k+1} = \mathbf{q}_k + h \mathbf{M}^{-1} \mathbf{p}_{k+1/2}, \quad (16.62)$$

$$\mathbf{p}_{k+1} = \mathbf{p}_{k+1/2} - \frac{h}{2} \nabla U(\mathbf{q}_{k+1}). \quad (16.63)$$

两次动量剪切和一次位置剪切都具有 Jacobian 矩阵的行列式 1, 所以复合映射体积保持。把 h 换成 $-h$ 并反向执行三步, 可以精确恢复起点, 所以映射具有时间可逆性。它还是辛积分器, 因为每个子步都是一个 Hamilton 子流。

这些性质可以直接从 Jacobian 核对。动量剪切 $S_U^c(\mathbf{q}, \mathbf{p}) = (\mathbf{q}, \mathbf{p} -$

$c\nabla U(\mathbf{q})$ 与位置剪切 $S_K^h(\mathbf{q}, \mathbf{p}) = (\mathbf{q} + h\mathbf{M}^{-1}\mathbf{p}, \mathbf{p})$ 的 Jacobian 分别为

$$G_U = \begin{bmatrix} \mathbf{I} & \mathbf{0} \\ -c\nabla^2 U & \mathbf{I} \end{bmatrix}, \quad G_K = \begin{bmatrix} \mathbf{I} & h\mathbf{M}^{-1} \\ \mathbf{0} & \mathbf{I} \end{bmatrix}.$$

由于 $\nabla^2 U$ 与 $\mathbf{M}^{-1}$ 对称, 直接相乘可得 $G_U^\top J G_U = J$ 和 $G_K^\top J G_K = J$ 。蛙跳映射是 $S_U^{h/2} \circ S_K^h \circ S_U^{h/2}$, 而辛映射的复合仍为辛映射。每个三角 Jacobian 的行列式为 1, 也再次给出体积保持。

令动量翻转为 $R(\mathbf{q}, \mathbf{p}) = (\mathbf{q}, -\mathbf{p})$, 并记一步蛙跳为 Ψ_h 。三步的对称排列给出

$$R \circ \Psi_h \circ R = \Psi_h^{-1} = \Psi_{-h}.$$

所以可逆性不是简单的 $\Psi_h = \Psi_h^{-1}$, 而是在反向运动时同时翻转动量。

蛙跳法一般不精确保持原 Hamilton 量。它对固定有限时间具有二阶全局精度, 并在合适光滑和步长条件下近似保持一个修正 Hamilton 量, 所以长时间能量误差常表现为有界振荡, 而非单向漂移。“可逆”“体积保持”“辛”和“能量误差小”是相关但不同的性质; 验证其中一项不能自动推出其余各项。

示例 16.21 谐振子的精确与数值轨道 取 $U(q) = q^2/2$ 、 $M = 1$ 。Hamilton 方程为

$$\dot{q} = p, \quad \dot{p} = -q,$$

精确轨迹沿圆 $q^2 + p^2 = \text{常数}$ 旋转。蛙跳一步可写成

$$\begin{bmatrix} q_{k+1} \\ p_{k+1} \end{bmatrix} = \begin{bmatrix} 1 - h^2/2 & h \\ -h + h^3/4 & 1 - h^2/2 \end{bmatrix} \begin{bmatrix} q_k \\ p_k \end{bmatrix}.$$

该矩阵行列式为 1、迹为 $2 - h^2$ 。其特征值在单位圆上且不退化的条件是 $|2 - h^2| < 2$, 即 $0 < h < 2$ 。在这个稳定范围内, 数值轨迹沿接近圆的闭曲线运动, 原能量会有小幅周期误差; 步长过大时, 即使每一步仍可逆且行列式为 1, 轨迹也可能不稳定。几何结构保持不能替代步长稳定性检查。

16.9.5 Hamilton 蒙特卡洛用接受校正修复离散误差

若目标密度满足 $\pi(\mathbf{q}) \propto \exp[-U(\mathbf{q})]$, 再引入高斯动量 $\mathbf{p} \sim \mathcal{N}(\mathbf{0}, \mathbf{M})$, 联合密度正比于 $\exp[-H(\mathbf{q}, \mathbf{p})]$ 。精确 Hamilton 流同时保持 H 和体积, 因而保持该联合密度。数值蛙跳产生候选 $(\mathbf{q}', \mathbf{p}')$ 时存在能量误差

$$\Delta H = H(\mathbf{q}', \mathbf{p}') - H(\mathbf{q}, \mathbf{p}).$$

Metropolis 接受概率

$$\alpha = \min\{1, \exp(-\Delta H)\} \quad (16.64)$$

结合可逆、体积保持的提议映射，恢复对目标联合分布的详细平衡。拒绝时保留原位置，动量翻转用于明确反向提议。

更具体地，令 $\rho(\mathbf{z}) \propto \exp[-H(\mathbf{z})]$ ，把若干步蛙跳与末端动量翻转合成映射 T 。上面的可逆性给出 $T(T(\mathbf{z})) = \mathbf{z}$ ，体积保持给出 $|\det \nabla T| = 1$ 。于是成对状态间的接受概率满足

$$\rho(\mathbf{z}) \min\left\{1, \frac{\rho(T\mathbf{z})}{\rho(\mathbf{z})}\right\} = \min\{\rho(\mathbf{z}), \rho(T\mathbf{z})\} = \rho(T\mathbf{z}) \min\left\{1, \frac{\rho(\mathbf{z})}{\rho(T\mathbf{z})}\right\}.$$

这就是确定性提议上的详细平衡；Jacobian 若不为 1，接受比还必须包含相应体积因子。每轮重新抽取服从 $\mathcal{N}(\mathbf{0}, \mathbf{M})$ 的动量也保持联合目标密度，边缘化动量后才得到位置目标 $\pi(\mathbf{q})$ 。

接受校正保证的是不变分布，不是独立样本、快速混合或有限预算精度。步长太大会导致频繁拒绝，轨迹太短会导致高自相关，质量矩阵不合适会使不同方向的时间尺度失配。另一方面，Hamilton 轨迹不要求能量持续下降。采样希望沿等能面远距离移动后保持目标分布，优化则希望找到低目标值；把 Hamilton 动力学解释成“更快的梯度下降”会混淆这两个目标。

16.10 本章小结

状态把过去对未来的作用压缩进当前变量。给定初值与输入，差分方程直接生成递推，常微分方程通过流映射生成连续轨迹。局部 Lipschitz 条件保证局部唯一解，全局解还需要增长或有界性控制。线性时不变系统可用矩阵指数求解，时变系统则需要保留状态转移矩阵的时间顺序。

离散化近似连续流。Euler、Runge-Kutta 与零阶保持的误差来源不同，连续系统稳定也不保证任意步长的数值递推稳定。仿射更新的结合律允许前缀扫描，却不允许交换时间次序。稳定性同样要区分平衡点不离开、轨迹趋近平衡和输入作用。谱决定线性系统的长期行为，Lyapunov 函数把更一般的稳定性转成标量下降，非正规系统则提醒我们长期衰减可以伴随短时放大。

加入过程噪声后，状态方程传播分布；加入观测噪声后，观测历史通过条件化形成滤波分布。在线性高斯及独立噪声条件下，Kalman 递推由一次联合高斯条件化精确得到，RTS 递推再利用未来观测修正过去边缘。这些是有限时域结论。稳态增益和极限协方差还需要第 18 章建立的可检测性等系统条件，非线性或非高斯模型也需要明确近似对象。

随机参数递推的平均 ODE 只描述平均方向。非对称线性漂移应检查

特征值实部、对称部分或 Lyapunov 方程，不能把一般漂移矩阵当作目标 Hessian 矩阵。同策略线性 TD 的加权 Markov 收缩可给出稳定漂移，离策略分布改变后必须重新证明。平均稳定仍不能替代步长、噪声、混合和迭代有界性。

连续时间噪声具有平方根增量和非零二次变差。这使布朗路径不能作为普通可微输入，并使 Itô 公式保留二阶修正。SDE 描述随机路径，Fokker-Planck 方程描述边缘密度，Euler-Maruyama 的强弱误差又是数值近似性质。Hamilton 动力学则保持能量与相空间几何；蛙跳的可逆和体积保持帮助构造采样提议，但不等于精确守恒，也不等于优化下降。

由此，章首问题可以分成两部分回答：状态方程和噪声条件决定轨迹或分布怎样演化，观测历史和条件化规则决定能够推断什么。第 17 章将在这些动态之上评价行动后果，第 18 章再让输入由反馈主动选择，并建立稳态估计、最优控制与安全约束所需的结构条件。

决策理论与动态风险

第 16 章说明了给定输入后状态怎样演化，第 8 章则说明给定观测后可以怎样更新结果分布。但分布本身不会告诉我们应该采取什么行动。即使两个分类器给出完全相同的患病概率，筛查系统与确诊系统也可能采用不同阈值，因为漏诊和误报的后果不同。决策需要在概率之外再给出行动集合和损失，并说明怎样汇总随机后果。

当行动还会改变下一时刻的状态时，单步比较又不够。当前多付一点成本，可能换来以后更好的状态或更有用的信息；当前平均成本较低，也可能隐藏小概率的严重损失。本章由单步 Bayes 决策建立“分布加损失”的共同语言，再比较均值、分位数、条件风险价值和鲁棒目标各自在评价什么。随后把行动放入有限状态的动态过程，从条件期望推导有限时域与折扣动态规划，并用线性规划对偶连接价值函数和占用流量。

信息价值和动态风险从两个方向扩展这一基准。前者问提前获得一项观测能否改变后续行动，后者问在每个历史下应怎样评价剩余损失。静态尾部准则、嵌套条件风险和最坏模型递推可能使用相似的优化式，却不一定定义同一个目标。贯穿本章的判断原则是：先写清随机对象、可用信息和允许行动，再检查所用风险准则能否与时间递推相容。

17.1 损失与 Bayes 决策

17.1.1 预测分布需要通过损失才能比较行动

设观测为 X ，未知结果为 $Y \in \mathcal{Y}$ ，可选行动属于 $\mathcal{A}$ 。损失函数

$$\ell : \mathcal{A} \times \mathcal{Y} \rightarrow \mathbb{R}$$

规定结果为 y 时采取行动 a 要付出多少代价。给定 $X = x$ 以后，结果仍然不确定，因此应比较各行动的**条件风险**（conditional risk）

$$r(a | x) = \mathbb{E}[\ell(a, Y) | X = x]. \quad (17.1)$$

若条件分布以概率核给出, 式 (17.1) 就是

$$r(a | x) = \int_Y \ell(a, y) P(dy | x).$$

有限类别时, 积分退化为 $\sum_y \ell(a, y) p(y | x)$ 。

在条件风险达到最小值时, 任取

$$a^*(x) \in \arg \min_{a \in \mathcal{A}} r(a | x) \quad (17.2)$$

称为一个 **Bayes 行动** (Bayes action), 映射 $\delta^* : x \mapsto a^*(x)$ 称为 **Bayes 决策规则** (Bayes decision rule)。这里的 “Bayes” 指按照给定条件分布最小化后验期望损失。条件分布可以来自先验与似然的更新, 也可以由其他概率模型给出; Bayes 公式负责更新信念, Bayes 规则负责把信念转成行动, 两者不是同一步。

若决策规则为 δ , 其总体风险为

$$R(\delta) = \mathbb{E}[\ell(\delta(X), Y)]. \quad (17.3)$$

全期望公式给出

$$R(\delta) = \mathbb{E}[r(\delta(X) | X)].$$

因此, 只要式 (17.2) 中的逐点最小值可测地选取, $r(\delta^*(x) | x) \leq r(\delta(x) | x)$ 便在积分后推出 $R(\delta^*) \leq R(\delta)$ 。有限行动集合中可按固定次序处理并列, 可测选择没有额外困难; 一般行动空间还要核对损失的可测性、下半连续性以及最小值是否达到。

示例 17.1 有限损失表的逐项计算 设结果 $Y \in \{y_0, y_1\}$, 两个行动的损失表为

	y_0	y_1
a_0	0	6
a_1	2	1

在某个观测 x 处, 设 $\mathbb{P}(Y = y_1 | X = x) = 1/4$ 。于是

$$r(a_0 | x) = \frac{3}{4} \times 0 + \frac{1}{4} \times 6 = \frac{3}{2}, \quad r(a_1 | x) = \frac{3}{4} \times 2 + \frac{1}{4} \times 1 = \frac{7}{4}.$$

Bayes 行动是 a_0 , 因为它比较的是按条件概率加权后的整行损失, 而不是逐列挑选较小数字。若结果扩展为有限集合 $\{y_1, \dots, y_m\}$, 同一计算变成 $r(a | x) = \sum_{j=1}^m \ell(a, y_j) \mathbb{P}(Y = y_j | X = x)$ 。

这个逐点选择确实给出总体最优, 而不只是局部启发式。对任意使用同

一观测 X 的可测规则 δ ，塔式法则和逐点最小性依次给出

$$\begin{aligned} R(\delta^*) &= \mathbb{E} [\mathbb{E} \{\ell(\delta^*(X), Y) \mid X\}] \\ &= \mathbb{E} \left[\min_{a \in \mathcal{A}} r(a \mid X) \right] \leq \mathbb{E} [r(\delta(X) \mid X)] = R(\delta). \end{aligned}$$

这里要求各项期望存在；有限行动保证可以按固定次序选取第一个最小行动。若 $\mathcal{A}$ 连续， $\inf_a r(a \mid x)$ 可能不达到，逐点最优行动也可能无法可测地拼成规则，因而不能直接沿用有限集合的结论。

17.1.2 不同错误代价改变分类阈值

考虑二分类 $Y \in \{0, 1\}$ 与预测行动 $a \in \{0, 1\}$ 。记

$$p(x) = \mathbb{P}(Y = 1 \mid X = x),$$

并设正确预测的损失为零，把假阳性的损失记为 $c_{\text{FP}} > 0$ ，假阴性的损失记为 $c_{\text{FN}} > 0$ 。两个行动的条件风险分别为

$$r(1 \mid x) = c_{\text{FP}}(1 - p(x)), \quad (17.4)$$

$$r(0 \mid x) = c_{\text{FN}}p(x). \quad (17.5)$$

选择 $a = 1$ 当且仅当第一项不大于第二项，即

$$p(x) \geq \frac{c_{\text{FP}}}{c_{\text{FP}} + c_{\text{FN}}}. \quad (17.6)$$

在等号处两个行动风险相同，可以按业务约定处理并列。

若两类错误代价相同，阈值是 $1/2$ 。漏诊代价增大时，式 (17.6) 的阈值下降，系统会更愿意预测阳性。概率模型没有发生变化，变化的是概率进入行动比较的方式。这也说明概率校准和决策质量不能互相替代：校准良好的 $p(x)$ 仍需配合正确损失，错误的损失设定则会把准确概率转成不合适的行动。

示例 17.2 同一概率对应不同合理行动 设某个样本的阳性概率为 $p(x) = 0.3$ 。在对称零一损失下，阈值为 0.5 ，Bayes 行动是预测阴性。若漏诊损失为 9 ，误报损失为 1 ，阈值降为 $1/(1+9) = 0.1$ ，同一概率对应的 Bayes 行动改为预测阳性。这个教学数值没有说明哪组代价适合真实任务；它只展示决策规则还依赖概率之外的价值判断。

17.1.3 拒答把“不行动”也纳入候选

模型不确定时，系统可以把样本交给人工复核，而不是被迫给出类别。令类别集合为 $\{1, \dots, K\}$ ，分类错误使用零一损失，并增加拒答行动 $\perp$ ，其固定损失为 $c_R \in (0, 1)$ 。若

$$p_{\max}(x) = \max_k \mathbb{P}(Y = k \mid X = x),$$

预测最可能类别的条件风险为 $1 - p_{\max}(x)$ ，拒答风险为 c_R 。因此最优规则为

$$\delta^*(x) = \begin{cases} \arg \max_k \mathbb{P}(Y = k \mid X = x), & p_{\max}(x) \geq 1 - c_R, \\ \perp, & p_{\max}(x) < 1 - c_R. \end{cases} \quad (17.7)$$

拒答不是概率模型中的新类别，而是一项具有自身代价的行动。

为描述选择性预测的整体表现，定义**覆盖率** (coverage)

$$\text{Coverage}(\delta) = \mathbb{P}\{\delta(X) \neq \perp\},$$

并在覆盖率为正时定义接受样本上的条件风险

$$R_{\text{acc}}(\delta) = \mathbb{E}[\ell(\delta(X), Y) \mid \delta(X) \neq \perp].$$

低接受风险可以通过拒绝更多样本获得，所以报告它时必须同时报告覆盖率。固定拒答成本最小化的是包含拒答损失的总体风险，并不等同于在任意指定覆盖率下直接最小化 R_{acc} 。

若人工复核数量有限，就不能逐个样本独立使用固定 c_R 。例如要求总体接受率至少为 κ ，可写成

$$\min_{\delta} R(\delta) \quad \text{s.t.} \quad \mathbb{P}\{\delta(X) \neq \perp\} \geq \kappa.$$

拉格朗日乘子把覆盖预算转成拒答的影子价格，在适当条件下仍得到阈值规则，但阈值由总体分布和预算共同决定。这类**选择性预测** (selective prediction) 控制的是在哪些输入上行动；它不等同于简单提高某个类别的错误代价。

示例 17.3 覆盖预算耦合两个观测点 设 X 等概率取 x_1, x_2 ，在两个点上作最优分类的条件错误风险分别为 0.2 和 0.4，拒答损失均为 0.1。若逐点比较，两个点都会拒答，因为 $0.1 < 0.2 < 0.4$ ，所得覆盖率为零。现在要求 $\text{Coverage}(\delta) \geq 1/2$ ，规则至少要接受一个点。接受 x_1

并拒答 x_2 的总体风险为

$$\frac{1}{2} \times 0.2 + \frac{1}{2} \times 0.1 = 0.15,$$

反向安排的风险为 $\frac{1}{2} \times 0.1 + \frac{1}{2} \times 0.4 = 0.25$ 。预算把两个观测点的选择联系起来，最优规则必须联合安排，而不能继续执行原来的逐点拒答。

在有限观测和行动问题中，若允许对每个观测随机选择行动，便可用选择概率作为变量，把风险与覆盖约束写成线性规划，强对偶给出相应影子价格。若只允许确定性规则，选择变量带有零一约束，问题一般会变成整数规划，普通线性规划的强对偶不能直接套用。连续分布或非凸策略类中，拉格朗日形式是否达到原约束问题的值，还要核对可行性、闭性和相应约束资格；不能仅凭乘子写法断言存在无间隙的阈值解。

17.1.4 随机化何时有用

给定 x ，若允许按概率核 $q(da | x)$ 随机选择行动，则条件风险为

$$\int_{\mathcal{A}} r(a | x) q(da | x) \geq \inf_{a \in \mathcal{A}} r(a | x).$$

有限或可数行动集合中，这个积分就是 $\sum_{a \in \mathcal{A}} q(a | x) r(a | x)$ 。它是各纯行动风险的加权平均，所以在没有额外耦合约束时，随机化不可能低于纯行动风险的下确界；当最小值达到时，它至多在多个 Bayes 行动并列时保持最优。但若不同输入共享总体预算、公平约束或资源约束，随机化可以精确满足一个纯规则无法达到的平均比例。此时它的作用来自可行域，不是来自期望损失本身偏好随机行动。

单步 Bayes 规则由行动、条件分布和损失三者共同确定。接下来保持行动及其随机损失不变，转而改变汇总随机后果的准则，考察平均损失之外还可以控制什么。

17.2 风险准则与鲁棒要求

17.2.1 均值相同不表示严重后果相同

本节统一采用“损失越小越好”的方向。设随机损失 L 可积。期望 $\mathbb{E}[L]$ 把所有结果按概率线性平均，便于比较和递推，但它可能掩盖稀有而严重的

后果。考虑两个教学方案

$$L_{\text{safe}} = 1, \quad L_{\text{tail}} = \begin{cases} 0, & \text{概率} 0.95, \\ 20, & \text{概率} 0.05. \end{cases}$$

两者期望损失都为 1，但第一个方案没有波动，第二个方案把全部平均损失集中到了最差 5% 的结果中。若任务不能承受这种尾部，单看均值就没有表达完整偏好。

方差 $\text{Var}(L)$ 衡量围绕均值的二次波动，均值-方差准则可以写成

$$\mathbb{E}[L] + \lambda \text{Var}(L), \quad \lambda \geq 0.$$

它同时惩罚高于和低于均值的偏离；对损失而言，意外变好也会增加方差。此外，方差不是单调风险准则：即使 $L_1 \leq L_2$ 逐点成立，较大的 L_2 也可能因方差更小而得到较低的均值-方差值。因此使用它时，应把“波动偏好”和“坏尾部偏好”分开说明。

风险准则的性质说明它怎样响应损失变化。对风险泛函 ρ ，单调性要求 $L \leq L'$ 几乎处处时 $\rho(L) \leq \rho(L')$ ；平移等变性要求确定增加 m 单位损失时 $\rho(L + m) = \rho(L) + m$ ；凸性要求

$$\rho(\tau L + (1 - \tau)L') \leq \tau \rho(L) + (1 - \tau)\rho(L'), \quad 0 \leq \tau \leq 1,$$

表示按同一场景逐点混合两项损失不会比风险值的同权平均更坏。若再有正齐次性和次可加性，便得到后文使用的**相干风险**(coherent risk measure)。期望满足这些性质。均值-方差准则至少要求二阶矩存在，并且一般不单调：令 L_1 以相同概率取 0, 2，令 $L_2 = 2$ ，则 $L_1 \leq L_2$ ，但当 $\lambda > 1$ 时， $\mathbb{E}[L_1] + \lambda \text{Var}(L_1) = 1 + \lambda > 2$ ，反而把逐点不大的 L_1 评得更差。

17.2.2 分位数与风险价值

对 $\alpha \in (0, 1)$ ，损失 L 的 α 分位数定义为

$$q_\alpha(L) = \inf\{z \in \mathbb{R} : \mathbb{P}(L \leq z) \geq \alpha\}. \quad (17.8)$$

在风险管理语境中，同一个量常称为**风险价值** (value at risk, VaR)，记作 $\text{VaR}_\alpha(L) = q_\alpha(L)$ 。它回答“至少 α 比例的结果不超过哪一损失水平”。VaR 只记录一个切点，不区分切点以上的损失究竟略高还是极其严重。

在上面的教学例子中，

$$\text{VaR}_{0.95}(L_{\text{safe}}) = 1, \quad \text{VaR}_{0.95}(L_{\text{tail}}) = 0.$$

按照本书采用的左分位数定义，第二个等式来自 $\mathbb{P}(L_{\text{tail}} \leq 0) = 0.95$ 。这并

不表示尾部方案更安全，而是表明分位点恰好落在概率质量为 0.95 的零损失原子上。离散分布中的边界质量必须进入尾部计算。

VaR 单调且平移等变，却不普遍满足次可加性。设互斥事件 E_1, E_2 各有概率 0.04，令 $L_i = \mathbb{I}\{E_i\}$ 。在 $\alpha = 0.95$ 时， $\text{VaR}_{0.95}(L_1) = \text{VaR}_{0.95}(L_2) = 0$ ，但 $L_1 + L_2$ 以概率 0.08 取 1，故

$$\text{VaR}_{0.95}(L_1 + L_2) = 1 > \text{VaR}_{0.95}(L_1) + \text{VaR}_{0.95}(L_2).$$

两个单独看来未进入最坏 5% 的事件，合并后超过了分位概率预算。这一反例针对一般分布；在额外分布结构下，VaR 仍可能具有更好的性质。

17.2.3 CVaR 平均最坏尾部的概率质量

条件风险价值 (conditional value at risk, CVaR) 不只看尾部起点，还平均最坏的 $1 - \alpha$ 概率质量¹。对可积损失，定义

$$\text{CVaR}_\alpha(L) = \inf_{\eta \in \mathbb{R}} \left\{ \eta + \frac{1}{1 - \alpha} \mathbb{E}[(L - \eta)_+] \right\}, \quad (u)_+ = \max\{u, 0\}. \quad (17.9)$$

参数 η 是候选尾部阈值。提高 η 会直接增加第一项，却会减少超过阈值的剩余损失；最优点在两种变化之间平衡。

记式 (17.9) 中花括号内的函数为 $\phi(\eta)$ 。对 $h > 0$ ，逐点考察正部函数可得

$$\begin{aligned} \phi'_+(\eta) &= 1 - \frac{\mathbb{P}(L > \eta)}{1 - \alpha}, \\ \phi'_-(\eta) &= 1 - \frac{\mathbb{P}(L \geq \eta)}{1 - \alpha}. \end{aligned}$$

ϕ 是凸函数，所以 η 最优当且仅当

$$\phi'_-(\eta) \leq 0 \leq \phi'_+(\eta),$$

也就是

$$\mathbb{P}(L < \eta) \leq \alpha \leq \mathbb{P}(L \leq \eta). \quad (17.10)$$

因此任一满足条件的 α 分位数都可作为最优阈值。这个推导也解释了为何离散原子不能直接丢掉：最优阈值处的左右导数可能不同。

令 $q = q_\alpha(L)$ 。由 $\mathbb{P}(L > q) \leq 1 - \alpha$ 及 $\mathbb{P}(L \geq q) \geq 1 - \alpha$ ，式 (17.9) 可改写为

$$\text{CVaR}_\alpha(L) = \frac{\mathbb{E}[L \mathbb{I}\{L > q\}] + q((1 - \alpha) - \mathbb{P}(L > q))}{1 - \alpha}. \quad (17.11)$$

第二项从 $L = q$ 的原子中补足尾部质量。当 $\mathbb{P}(L \geq q) = 1 - \alpha$ 时，式 (17.11) 可简写成 $\mathbb{E}[L | L \geq q]$ ；分布在 q 处连续是保证该等式成立的常见

¹ R. T. Rockafellar, S. Uryasev, *Optimization of Conditional Value-at-Risk* In The Journal of Risk, 2000, vol. 2, no. 3, pp. 21–41

充分条件，却不是必要条件。无条件使用这个条件期望公式，会在离散分布中平均过多概率质量。

对 L_{safe} ，式 (17.11) 给出 $\text{CVaR}_{0.95} = 1$ 。对 L_{tail} ，最差 5% 恰好全部位于损失 20，所以

$$\text{CVaR}_{0.95}(L_{\text{tail}}) = 20.$$

期望看不出两者差异，VaR 又在原子边界上给出 0，CVaR 则直接反映严重尾部。

17.2.4 风险包络把 CVaR 写成最坏重加权

CVaR 还有一个对鲁棒决策有用的表达。设 $L \in L^1(P)$ ，则

$$\text{CVaR}_\alpha(L) = \sup_{\zeta} \left\{ \mathbb{E}_P[\zeta L] : 0 \leq \zeta \leq \frac{1}{1-\alpha}, \mathbb{E}_P[\zeta] = 1 \right\}. \quad (17.12)$$

ζ 是相对于原分布的密度比。上界 $1/(1-\alpha)$ 允许对坏结果加权，却不允许把全部质量压到任意小于 $1-\alpha$ 的事件上。

先看有限分布。对结果 i 及原概率 p_i ，令 $q_i = p_i \zeta_i$ 。右侧成为线性规划

$$\max_{\mathbf{q}} \sum_i q_i L_i \quad \text{s.t.} \quad 0 \leq q_i \leq \frac{p_i}{1-\alpha}, \quad \sum_i q_i = 1.$$

最优解从最大损失开始填充允许的概率质量，直到总质量为 1；若最后一个损失值处只能取部分质量，正好得到式 (17.11) 中的边界补足。一般表达可由相同的凸对偶关系得到。式 (17.12) 说明 CVaR 是特定风险包络中的最坏期望，但这不意味着任意分布鲁棒目标都等于 CVaR。

式 (17.9) 还可直接验证 CVaR 的基本性质。若 $L \leq L'$ ，则对每个 η 都有 $(L - \eta)_+ \leq (L' - \eta)_+$ ，取下确界得到单调性。把 $\eta' = \eta - m$ 代入 $L + m$ 的优化式，得到 $\text{CVaR}_\alpha(L + m) = \text{CVaR}_\alpha(L) + m$ 。对 $t \geq 0$ ，令 $\eta = t\bar{\eta}$ 可得正齐次性； $t = 0$ 由归一化单独成立。最后，对任意 η_1, η_2 ，正部函数满足

$$(L_1 + L_2 - \eta_1 - \eta_2)_+ \leq (L_1 - \eta_1)_+ + (L_2 - \eta_2)_+.$$

将这个不等式代入优化表达，并分别对 η_1, η_2 取下确界，得到次可加性。正齐次性与次可加性又推出凸性。因此，对可积损失，CVaR 是单调、平移等变、正齐次且次可加的相干风险；这些性质不依赖损失分布连续。

17.2.5 机会约束、最坏情形与分布鲁棒性

若要求损失超过阈值 b 的概率不能太大，可以使用**机会约束** (chance constraint)

$$\mathbb{P}(L > b) \leq \varepsilon. \quad (17.13)$$

它控制违规事件的概率，不区分违规后超出阈值多少。条件

$$\text{CVaR}_{1-\epsilon}(L) \leq b$$

蕴含 $\text{VaR}_{1-\epsilon}(L) \leq b$ ，进而蕴含式 (17.13)；这个 CVaR 替代通常更保守，却同时控制尾部幅度。反方向一般不成立，因为小概率违规可以具有任意大的损失。

若模型由参数 $\theta \in \Theta$ 确定，最坏情形目标

$$\inf_a \sup_{\theta \in \Theta} \mathbb{E}_{P_\theta}[\ell(a, Y)]$$

直接比较指定模型集合中的最坏期望。**分布鲁棒优化** (distributionally robust optimization, DRO) 则把候选分布放入由距离、矩条件或散度定义的集合 $\mathcal{P}$ ，优化

$$\inf_a \sup_{Q \in \mathcal{P}} \mathbb{E}_Q[\ell(a, Y)].$$

集合如何构造决定保证针对哪些分布；仅把“鲁棒”写进目标名称，不会自动覆盖真实分布。

仍看 L_{safe} 与 L_{tail} 。取事故阈值 $b = 10$ 和 $\epsilon = 0.05$ ，前者的违规概率为零，后者恰为 0.05，所以两者都满足机会约束；但二者的 $\text{CVaR}_{0.95}$ 分别为 1 和 20。若尾部方案中损失 20 的概率并非已知，而只知道 $p \in [0.02, 0.08]$ ，则其最坏期望为 $\max_p 20p = 1.6$ ，而机会约束在整个模型集合上并不成立，因为 $p = 0.08 > 0.05$ 。逐路径最坏损失仍是 20。同一有限损失表由此产生了尾部平均、违规概率、最坏期望和逐路径上界四个不同数值。

在有限样本空间中，若 $\mathcal{P}$ 是概率单纯形内的非空闭集，内层期望关于概率向量线性，紧致性保证最坏分布达到最大值。若集合排除了某些结果，保证也只覆盖其共同支持；若集合由估计距离球构造，“真实分布落在球内”还需要另行给出抽样置信保证。交换 $\inf_a$ 与 $\sup_Q$ 或把内层最大值改写成对偶问题，则还需要凸性、紧致性、连续性或相应约束资格，不能从有限最大值的存在自动推出。

风险准则、模型扰动与安全约束改变的是三个不同对象。CVaR 改变同一损失分布的汇总方式，最坏模型改变允许的数据生成分布，机会约束限制特定事件概率。它们可以组合，但组合前必须明确内外层优化次序。下面先回到期望准则，建立行动会改变未来状态时的基准递推。

17.3 序贯策略与动态规划

17.3.1 Markov 决策过程把行动接入状态演化

考虑有限时域 $t = 0, \dots, H$ 。状态 S_t 属于有限集合 $\mathcal{S}$ ，在状态 s 可选行动属于非空有限集合 $\mathcal{A}(s)$ 。记时刻 t 采取行动前的历史为

$$H_t = (S_0, A_0, \dots, S_t).$$

采取行动 a 后，付出阶段成本 $c_t(s, a)$ ，下一状态按转移概率

$$P_t(s' | s, a) = \mathbb{P}(S_{t+1} = s' | S_t = s, A_t = a)$$

生成，末端再付出 $c_H(S_H)$ 。更具体地，MDP 的 Markov 条件要求，对任一末状态为 s 的历史 h_t ，后续转移核满足

$$\mathbb{P}(S_{t+1} = s' | H_t = h_t, A_t = a) = P_t(s' | s, a).$$

这些对象组成有限时域 **Markov 决策过程** (Markov decision process, MDP)²。这里的 S_t 承担前章状态 $\mathbf{x}_t$ 的角色， A_t 承担输入 $\mathbf{u}_t$ 的角色；区别在于本章先使用有限状态与有限行动，并以转移概率取代线性状态方程。

² M. L. Puterman, *Markov Decision Processes: Discrete Stochastic Dynamic Programming*, Wiley, 1994

一般策略可以根据全部历史随机选择行动， $\pi_t(a | H_t)$ 。若只依赖当前状态，就称为 Markov 策略；若选择确定行动，写成 $a = \pi_t(s)$ 。状态必须保留预测未来成本与转移所需的信息。若真实过程还依赖未记录历史，直接把观测称为“状态”并不会使 Markov 性质成立。

对末状态为 s 的一段历史 h_t ，一般策略的继续成本应定义为

$$J_t^\pi(h_t) = \mathbb{E}_{h_t}^\pi \left[\sum_{k=t}^{H-1} c_k(S_k, A_k) + c_H(S_H) \right]. \quad (17.14)$$

这里的 $\mathbb{E}_{h_t}^\pi$ 表示固定已有历史 h_t ，再由策略与转移核生成后续过程；即使该历史在某个初始分布下概率为零，这个继续过程仍有定义。若 π 为 Markov 策略，Markov 条件使 $J_t^\pi(h_t)$ 只依赖末状态 s ，此时把它记作 $V_t^\pi(s)$ ，并由条件期望得到

$$V_t^\pi(s) = \sum_a \pi_t(a | s) \left[c_t(s, a) + \sum_{s'} P_t(s' | s, a) V_{t+1}^\pi(s') \right], \quad (17.15)$$

边界条件为 $V_H^\pi(s) = c_H(s)$ 。当前成本与未来价值在同一条件期望中相加，塔式性质负责把后续随机性压缩成 V_{t+1}^π 。

17.3.2 有限时域 Bellman 递推与策略比较

由末端向前定义候选最优成本

$$V_H^*(s) = c_H(s), \quad (17.16)$$

$$V_t^*(s) = \min_{a \in \mathcal{A}(s)} \left\{ c_t(s, a) + \sum_{s'} P_t(s' | s, a) V_{t+1}^*(s') \right\}. \quad (17.17)$$

定理 17.4 有限时域最优性原理 在上述有限 MDP 中，式 (17.17) 给出的 $V_t^*(s)$ 满足：对每个末状态为 s 的历史 h_t ，

$$V_t^*(s) = \inf_{\pi} J_t^{\pi}(h_t),$$

其中下确界遍历所有允许的历史依赖随机继续策略。每个时刻和状态选择式 (17.17) 中任一最小行动，得到的确定性 Markov 策略最优，因此有限状态行动下该下确界可以达到。

证明. 证明采用逆向归纳。时刻 H 没有行动，结论由式 (17.16) 成立。假设对每段末状态为 s' 的历史 h_{t+1} ， $V_{t+1}^*(s')$ 已经等于从该历史继续的最小成本。固定时刻 t 的一段历史 h_t ，其末状态为 s 。任何策略在该历史下先产生一个行动分布。给定行动 a 和下一状态 s' 后，归纳假设说明后续条件期望成本至少为 $V_{t+1}^*(s')$ 。Markov 条件保证下一状态分布为 $P_t(\cdot | s, a)$ ，因此该策略从 h_t 开始的成本至少为

$$\sum_a \pi_t(a | h_t) \left[c_t(s, a) + \sum_{s'} P_t(s' | s, a) V_{t+1}^*(s') \right].$$

右侧是各行动括号项的凸组合，不小于其中最小值，也就是 $V_t^*(s)$ 。

反过来，在当前状态选择达到最小值的行动，并在下一时刻采用归纳假设给出的最优 Markov 策略，每一步不等式都取等号，所以能够达到 $V_t^*(s)$ 。由 $t = H - 1, \dots, 0$ 归纳，结论成立。 ■

这个证明同时解释了 Markov 策略为何足够：在已知模型和期望总成本目标下，历史对未来的作用已经由当前状态概括。若状态遗漏信息、目标依赖整段轨迹的其他统计量，或策略还受跨历史预算约束，必须扩充状态或重新证明这一结论。

示例 17.5 两阶段路线选择 初始状态 s_0 有“稳妥”和“捷径”两个行动，当前成本都为零。稳妥行动确定进入末端损失 2 的状态；捷径以概率 0.8 进入损失 0 的状态，以概率 0.2 进入损失 6 的状态。末端价

值就是末端损失，因此

$$Q_0(s_0, \text{稳妥}) = 2, \quad Q_0(s_0, \text{捷径}) = 0.8 \times 0 + 0.2 \times 6 = 1.2.$$

期望成本准则选择捷径。这里没有声称捷径在每条路径上更好；Bellman 递推比较的是给定状态和行动后的条件期望。

17.3.3 无限折扣问题的固定点

现在令转移核 P 和有界阶段成本 c 不随时间改变，并取折扣因子 $\gamma \in [0, 1)$ 。这里的 π 可以是任意历史依赖随机策略，其价值为

$$V^\pi(s) = \mathbb{E}^\pi \left[\sum_{t=0}^{\infty} \gamma^t c(S_t, A_t) \middle| S_0 = s \right]. \quad (17.18)$$

若 $|c(s, a)| \leq C$ ，几何级数保证 $|V^\pi(s)| \leq C/(1 - \gamma)$ 。

在有界函数空间上定义 Bellman 最优算子

$$(TV)(s) = \min_{a \in \mathcal{A}(s)} \left\{ c(s, a) + \gamma \sum_{s'} P(s' | s, a) V(s') \right\}. \quad (17.19)$$

对两组实数 (u_a) 与 (v_a) ，有

$$\left| \min_a u_a - \min_a v_a \right| \leq \max_a |u_a - v_a|.$$

再利用转移概率非负且和为 1，得到

$$\begin{aligned} |(TV)(s) - (TW)(s)| &\leq \gamma \max_a \left| \sum_{s'} P(s' | s, a) (V(s') - W(s')) \right| \\ &\leq \gamma \|V - W\|_\infty. \end{aligned} \quad (17.20)$$

对 s 取最大值得

$$\|TV - TW\|_\infty \leq \gamma \|V - W\|_\infty. \quad (17.21)$$

有限状态上的有界函数空间在上确界范数下完备。由第 2.14 号定理， T 有唯一不动点 V^* ，价值迭代 $V^{(k+1)} = TV^{(k)}$ 从任意有界初值收敛，并满足

$$\|V^{(k)} - V^*\|_\infty \leq \gamma^k \|V^{(0)} - V^*\|_\infty. \quad (17.22)$$

在每个状态选择达到 $TV^* = V^*$ 的行动，可得到确定性平稳贪心策略。

为补上最后一步，记该贪心策略为 π^* ，并令

$$(T_{\pi^*} V)(s) = c(s, \pi^*(s)) + \gamma \sum_{s'} P(s' | s, \pi^*(s)) V(s').$$

与前面的证明相同, T_{π^*} 也是 γ 压缩, 其唯一固定点正是 V^{π^*} 。贪心选择又使 $T_{\pi^*}V^* = TV^* = V^*$, 所以固定点唯一性给出 $V^{\pi^*} = V^*$ 。这说明 Bellman 固定点不仅存在, 而且确实由一个平稳确定性策略达到。

还需把这个固定点与所有其他允许策略比较。由 $V^* = TV^*$, 对每个状态行动对都有 Bellman 不等式

$$V^*(s) \leq c(s, a) + \gamma \sum_{s'} P(s' | s, a) V^*(s').$$

沿任意历史依赖随机策略 π 实际选择的行动逐步条件化, 并迭代 n 步, 得到

$$V^*(s) \leq \mathbb{E}_s^\pi \left[\sum_{t=0}^{n-1} \gamma^t c(S_t, A_t) + \gamma^n V^*(S_n) \right]. \quad (17.23)$$

V^* 有界, 所以余项的绝对值至多为 $\gamma^n \|V^*\|_\infty$, 随 $n \rightarrow \infty$ 趋于零; 有界成本又保证折扣成本级数可积。令 $n \rightarrow \infty$ 便得到 $V^*(s) \leq V^\pi(s)$ 。结合 $V^{\pi^*} = V^*$, 贪心策略对全部允许的历史依赖随机策略最优。

$\gamma < 1$ 同时保证总成本有限并产生严格压缩。若令 $\gamma = 1$, 算子通常只能非扩张, 累计成本也可能发散。长期平均成本

$$\limsup_{T \rightarrow \infty} \frac{1}{T} \mathbb{E}^\pi \left[\sum_{t=0}^{T-1} c(S_t, A_t) \right]$$

需要平稳性、可达类或单链等额外条件, 并常以平均成本 g 和相对价值 h 满足

$$g + h(s) = \min_a \left\{ c(s, a) + \sum_{s'} P(s' | s, a) h(s') \right\}.$$

h 加常数后仍是解, 所以不能沿用折扣问题的唯一固定点结论。

有限状态行动使取最小值、可测性和策略选取都较直接。连续状态或行动下, 通常还要要求转移核可测、成本具有适当的下半连续性、可行动作对应非空且具有紧致性或其他强制性, 并用可测选择定理把逐状态最小行动拼成策略。部分可观测时, 真实状态不能直接作为策略输入; 只有在滤波信念能概括历史对未来的影响时, 才能把信念分布作为新的 Markov 状态。这些条件缺失时, 形式上的 $\inf$ 仍可写出, 却未必有达到它的可实施策略。

17.3.4 Bellman 不等式与占用流量的 LP 对偶

有限折扣 MDP 还能写成线性规划。给定初始分布 ρ , 考虑价值端原问题

$$\begin{aligned} \max_V \quad & (1 - \gamma) \sum_s \rho(s) V(s) \\ \text{s.t.} \quad & V(s) \leq c(s, a) + \gamma \sum_{s'} P(s' | s, a) V(s'), \quad s \in \mathcal{S}, a \in \mathcal{A}(s). \end{aligned} \quad (17.24)$$

任一可行 V 满足 $V \leq TV$ 。反复应用单调的 T , 并令迭代收敛到 V^* , 得到 $V \leq V^*$ 。而 $V^* = TV^*$ 本身可行, 所以它达到原问题最优值。

为每条 Bellman 不等式引入乘子 $d(s, a) \geq 0$ 。拉格朗日函数为

$$\begin{aligned} \mathcal{L}(V, d) = & (1 - \gamma) \sum_s \rho(s) V(s) \\ & - \sum_{s, a} d(s, a) \left[V(s) - c(s, a) - \gamma \sum_{s'} P(s' | s, a) V(s') \right]. \end{aligned}$$

收集每个 $V(s)$ 的系数。若要使 $\sup_V \mathcal{L}(V, d)$ 有限, 必须满足

$$\sum_a d(s, a) = (1 - \gamma) \rho(s) + \gamma \sum_{\bar{s}, \bar{a}} P(s | \bar{s}, \bar{a}) d(\bar{s}, \bar{a}), \quad s \in \mathcal{S}. \quad (17.25)$$

此时所有价值系数消失, 只剩 $\sum_{s, a} d(s, a) c(s, a)$ 。因此对偶问题为

$$\begin{aligned} \min_d \quad & \sum_{s, a} d(s, a) c(s, a) \\ \text{s.t.} \quad & \text{式 (17.25),} \\ & d(s, a) \geq 0. \end{aligned} \quad (17.26)$$

定理 3.8 保证两个有限 LP 的最优值相等。

式 (17.25) 不是抽象代数条件。对策略 π , 定义归一化折扣**占用度量** (occupancy measure)

$$d_\pi(s, a) = (1 - \gamma) \mathbb{E}_{S_0 \sim \rho}^\pi \left[\sum_{t=0}^{\infty} \gamma^t \mathbb{I}\{S_t = s, A_t = a\} \right]. \quad (17.27)$$

把到达状态 s 的流量按初始注入和前一步转移分开, 正好得到式 (17.25)。

逐项写出便是

$$\begin{aligned}
 \sum_a d_\pi(s, a) &= (1 - \gamma) \sum_{t=0}^{\infty} \gamma^t \mathbb{P}^\pi(S_t = s) \\
 &= (1 - \gamma) \rho(s) + \gamma(1 - \gamma) \sum_{t=0}^{\infty} \gamma^t \sum_{\bar{s}, \bar{a}} \mathbb{P}^\pi(S_t = \bar{s}, A_t = \bar{a}) P(s | \bar{s}, \bar{a}) \\
 &= (1 - \gamma) \rho(s) + \gamma \sum_{\bar{s}, \bar{a}} P(s | \bar{s}, \bar{a}) d_\pi(\bar{s}, \bar{a}).
 \end{aligned}$$

由第一行到第二行时分离 $t = 0$ ，把其余项的索引前移，再用全概率公式展开下一状态。对流量方程的状态 s 求和，并利用转移概率和为 1，可得

$$\sum_{s,a} d_\pi(s, a) = 1.$$

目标值则满足

$$\sum_{s,a} d_\pi(s, a) c(s, a) = (1 - \gamma) \mathbb{E}_{S_0 \sim \rho}^\pi \left[\sum_{t=0}^{\infty} \gamma^t c(S_t, A_t) \right]. \quad (17.28)$$

反过来，给定任一可行 d ，令

$$\pi_d(a | s) = \frac{d(s, a)}{\sum_{\bar{a}} d(s, \bar{a})}$$

用于分母为正的状态；零占用状态上的行动可以任意指定。记 $x_d(s) = \sum_a d(s, a)$ ，并把 $x_d(s)$ 与 $\rho(s)$ 按状态排列为列向量 $\mathbf{x}_d$ 与 $\boldsymbol{\rho}$ 。再令 $P_{\pi_d}(s' | s) = \sum_a \pi_d(a | s) P(s' | s, a)$ ，代入 π_d 后，流量方程变成

$$\mathbf{x}_d = (1 - \gamma) \boldsymbol{\rho} + \gamma \mathbf{P}_{\pi_d}^\top \mathbf{x}_d.$$

因为 $\gamma < 1$ ，矩阵 $\mathbf{I} - \gamma \mathbf{P}_{\pi_d}^\top$ 可由 Neumann 级数求逆，所以这个固定策略的折扣状态流量方程只有一个解。策略 π_d 实际产生的状态占用也满足同一方程，因而等于 $\mathbf{x}_d$ ，再由 $d(s, a) = x_d(s) \pi_d(a | s)$ 恢复同一个状态行动占用度量。由此，价值 LP 在找满足所有行动下界的最大价值，流量 LP 在找可实现的最小成本访问分布。

互补松弛进一步给出

$$d^*(s, a) > 0 \implies V^*(s) = c(s, a) + \gamma \sum_{s'} P(s' | s, a) V^*(s').$$

最优占用为正的行动必须在对应状态达到 Bellman 最小值。若采用未乘 $1 - \gamma$ 的占用量，流量方程的初始项变为 ρ ，总质量变为 $1/(1 - \gamma)$ ；两种约定都可使用，但目标与约束必须同步归一化。

上述 LP 推导依赖有限状态行动、有界成本与 $\gamma < 1$ 。连续状态下，占用

对象是测度，价值约束是函数不等式；强对偶还需要可测选择、紧致性和适当闭性条件，不能仅把有限求和替换成积分便宣称结论仍成立。

17.4 信息价值与探索

17.4.1 信息有价值是因为它可能改变行动

设未知环境参数为 Θ ，当前信息为 $\mathcal{G}$ ，相应信念为 $b(d\theta) = \mathbb{P}(\Theta \in d\theta \mid \mathcal{G})$ 。为把重点放在信息如何改变行动，本小节假设行动集合有限，并且各行动的损失可测且可积。一般行动空间中，下面的点态下确界还须可测，并且需要存在可测的最优或 ε -最优选择，才能对应观察后可实施的规则。若立即选择行动 a ，Bayes 风险为

$$\mathcal{R}(b) = \inf_a \mathbb{E}_{\theta \sim b}[\ell(a, \theta)].$$

现在可以先观察信号 Z ，其条件分布由核 $K(dz \mid \theta)$ 给出。观察 $Z = z$ 后，信念按 Bayes 规则更新为 b_z ，再选择适合该后验的行动。信号的**期望样本信息价值**（expected value of sample information, EVSI）定义为

$$\text{EVSI}(Z \mid b) = \mathcal{R}(b) - \mathbb{E}_{Z|b}[\mathcal{R}(b_Z)]. \quad (17.29)$$

这是“无信号时的最小风险”减去“看到信号后再行动的平均最小风险”。

EVSI 非负。证明不需要熵或互信息，只需注意观察后总可以忽略 Z ，继续采用原来的行动。若无信号风险的下确界由 a^* 达到，则对每个 z ，

$$\mathcal{R}(b_z) \leq \mathbb{E}[\ell(a^*, \Theta) \mid Z = z, \mathcal{G}].$$

再对 Z 取期望并使用塔式性质，得到

$$\mathbb{E}_{Z|b}[\mathcal{R}(b_Z)] \leq \mathbb{E}[\ell(a^*, \Theta) \mid \mathcal{G}] = \mathcal{R}(b).$$

在一般行动空间中，若最优行动不达到但存在可测的 ε -最优选择，可改取风险不超过 $\mathcal{R}(b) + \varepsilon$ 的行动。相同推导给出观察后平均风险不超过 $\mathcal{R}(b) + \varepsilon$ ，再令 $\varepsilon \downarrow 0$ ，仍得到 EVSI 非负。若取得信号要付成本 k ，应比较净价值 $\text{EVSI} - k$ 。免费信息不会降低最优价值，不表示任何有成本的观测都值得获取。

若能够直接知道 Θ ，得到**完全信息价值**

$$\text{EVPI}(b) = \inf_a \mathbb{E}_b[\ell(a, \Theta)] - \mathbb{E}_b \left[\inf_a \ell(a, \Theta) \right]. \quad (17.30)$$

任意样本信号都是 Θ 的随机加工，决策者在知道 Θ 后可以模拟该信号，所以 $\text{EVSI} \leq \text{EVPI}$ 。等号只在信号已经保留当前决策所需的全部信息时成

立。

示例 17.6 辨别信号与无关信号 沿用二分类决策，设当前阳性概率为 0.3，假阳性损失为 1，假阴性损失为 9。不观察新信号时，预测阳性的风险为 0.7，预测阴性的风险为 2.7，故 $\mathcal{R}(b) = 0.7$ 。若免费信号 Z_{perf} 完全揭示类别，观察后总能选对，平均风险降为零，因而 $\text{EVSI}(Z_{\text{perf}} | b) = 0.7$ 。

另取一个与类别独立的公平硬币信号 Z_{coin} 。无论看到哪一面，后验阳性概率仍为 0.3，最优行动和风险都不变，所以 $\text{EVSI}(Z_{\text{coin}} | b) = 0$ 。若取得完全信号的成本为 0.8，其净价值反而为 -0.1。可辨别性、任务价值和扣除成本后的净收益是三个不同判断。

17.4.2 信息量与行动价值使用不同刻度

互信息衡量观察 Z 后关于 Θ 的不确定性平均减少多少，信息价值衡量最优决策损失减少多少。一个信号可以精确揭示与当前行动无关的参数，互信息很大而 EVSI 为零；另一个二元信号只在临界阈值附近略微改变信念，却可能翻转高代价行动，EVSI 很大。因此，主动获取信息时必须说明优化的是预测精度、熵减少还是决策价值。

当损失为对数评分且行动本身是预测分布时，信息增益与期望对数损失改善会形成直接联系。对一般分类代价、资源分配或控制损失，这种等价不再成立。使用熵作为查询代理时，需要证明它与任务损失之间的关系，不能只因二者都随信息变化便混用。

17.4.3 两臂选择中的探索收益

考虑两轮选择。已知臂每次成功概率为 0.6。未知臂的成功概率 Θ 只可能是 0.3 或 0.9，先验概率各为 1/2。当前未知臂的后验均值也是 0.6，所以若只看本轮期望收益，两臂并列。

若第一轮选择未知臂，成功的边缘概率为 0.6。观察成功后，

$$\mathbb{P}(\Theta = 0.9 | \text{成功}) = \frac{0.9 \times 0.5}{0.9 \times 0.5 + 0.3 \times 0.5} = 0.75,$$

下一轮未知臂的后验成功概率为 $0.75 \times 0.9 + 0.25 \times 0.3 = 0.75$ 。若第一轮失败，

$$\mathbb{P}(\Theta = 0.9 | \text{失败}) = \frac{0.1 \times 0.5}{0.1 \times 0.5 + 0.7 \times 0.5} = 0.125,$$

未知臂的后验成功概率降为 0.375，下一轮改选已知臂。因此“先试未知臂，再按结果选择”的两轮期望收益为

$$0.6 + 0.6 \times 0.75 + 0.4 \times 0.6 = 1.29. \quad (17.31)$$

始终选择已知臂的期望收益为 1.2。多出的 0.09 来自第一轮观测改变了第二轮行动，而不是来自未知臂当前均值更高。

这个例子把**探索** (exploration) 的核心作用写得很小：某个行动既产生即时结果，也产生影响后续选择的信息。若只剩一轮，信息没有后续使用机会，两臂又回到并列。若试验成本上升或先验差异缩小，探索价值也会改变。完整的多臂和强化学习算法还要处理未知参数估计、长时域规划和计算问题，本节只建立信息进入决策的数学位置。

上述更新假设两轮共享同一个不变参数 Θ ，并且每轮只观察所选臂的结果；未选臂的反事实结果不可见。若每轮同时观察所有臂，信息结构会改变；若成功概率随时间漂移而仍按固定 Θ 更新，后验和探索收益的计算都不再对应真实过程。

17.4.4 自适应获取改变证据条件

选择最不确定的样本、反复试验某个行动或在区间足够窄时停止，都会让数据取得规则依赖过去观测。信息价值说明为何要这样选择，却不自动保证选择后的估计仍然可靠。若希望报告置信区间或识别最优行动，需要回到第 9.2 节的停时条件和第 9.3 节的可预测设计，核对当前查询是否在当前噪声揭晓前确定，以及保证是否对全部查看时刻同时成立。

遗憾则使用另一比较口径。令 Y_t 为第 t 轮观察到的随机奖励，并定义给定环境参数 θ 时的平均奖励函数。记 $\mathcal{H}_{t-1}$ 为第 t 轮行动前可用的信息，要求 A_t 在 Y_t 揭晓前依据这些信息选定，并假设

$$\mathbb{E}[Y_t | \mathcal{H}_{t-1}, A_t = a, \Theta = \theta] = \mu(a, \theta) \quad \text{几乎处处.}$$

这个条件要求给定环境参数、历史和本轮行动后，奖励均值只由 (a, θ) 决定，因而排除了自适应选臂引入的历史选择效应；同时假设该均值不随轮次改变。若第 t 轮选择 A_t ，并取

$$a^*(\theta) \in \arg \max_a \mu(a, \theta),$$

则累计伪遗憾定义为

$$\text{Reg}_T(\theta) = \sum_{t=1}^T [\mu(a^*(\theta), \theta) - \mu(A_t, \theta)].$$

它在相同环境参数下，把算法所选行动的平均奖励与始终选择最优行动的平均奖励比较。若算法或 Θ 也是随机的，还可再对 $\text{Reg}_T(\Theta)$ 取期望。直接用实现奖励之差定义的随机遗憾还包含奖励噪声，不能与上述平均奖励差混为一谈。EVSI 衡量一项信息在当前决策问题中的期望价值。二者相关，却不能用一次信息增益直接替代长期遗憾证明。

17.5 条件风险、动态递推与时间一致性

17.5.1 静态尾部准则可能在到达分支后改变偏好

期望能够递推，是因为塔式性质把未来条件期望再平均回当前期望。若在初始时刻对整段累计损失一次性计算 CVaR，这项性质通常不再成立。下面的两阶段教学例子展示缺口。

初始时以相同概率进入节点 N 与节点 B 。节点 N 的损失固定为 2；在 B 中可以选择固定方案 F 或随机方案 R ：

$$L_F = 3.5, \quad L_R = \begin{cases} 0, & \text{条件概率 } 1/2, \\ 4, & \text{条件概率 } 1/2. \end{cases}$$

若初始时承诺在 B 选择 F ，总损失以概率 $1/2$ 取 2，以概率 $1/2$ 取 3.5，所以最坏一半的平均为

$$\text{CVaR}_{0.5}(L^F) = 3.5.$$

若承诺选择 R ，无条件损失分别以概率 $1/4, 1/2, 1/4$ 取 0, 2, 4。最坏一半的概率质量由全部损失 4 和一半的损失 2 组成，故

$$\text{CVaR}_{0.5}(L^R) = \frac{(1/4) \times 4 + (1/4) \times 2}{1/2} = 3.$$

初始静态 CVaR 因此严格偏好承诺 R 。

但真正到达 B 以后，条件分布已经改变。此时

$$\text{CVaR}_{0.5}(L_F | B) = 3.5, \quad \text{CVaR}_{0.5}(L_R | B) = 4,$$

决策者会改选 F 。初始评价时，节点 N 的损失 2 占用了静态尾部的一部分；到达 B 后，节点 N 已经排除，尾部质量只在 B 的条件分布中重新分配。偏好反转来自条件化改变了排序，不是 CVaR 计算错误，也不表示所有风险准则都会出现同样冲突。普通期望仍由塔式法则保持递推。

17.5.2 条件风险映射按当前信息评价未来损失

令

$$\mathcal{F}_0 \subseteq \mathcal{F}_1 \subseteq \cdots \subseteq \mathcal{F}_H$$

表示随历史增长的信息。一步**条件风险映射** (conditional risk mapping)

$$\rho_t : L^\infty(\mathcal{F}_{t+1}) \longrightarrow L^\infty(\mathcal{F}_t)$$

把下一时刻可知的有界随机损失, 转换成当前信息下可比较的风险。常用的两项性质是:

$$Z \leq Z' \implies \rho_t(Z) \leq \rho_t(Z'), \quad \text{单调性,} \quad (17.32)$$

$$\rho_t(Z + M) = \rho_t(Z) + M, \quad M \in L^\infty(\mathcal{F}_t), \quad \text{平移等变性.} \quad (17.33)$$

第一项表示逐点更大的未来损失不应得到更低风险; 第二项表示当前已经确定的成本可以直接提出风险映射。通常还约定 $\rho_t(0) = 0$ 。条件期望 $\rho_t(Z) = \mathbb{E}[Z | \mathcal{F}_t]$ 满足这些性质。

条件 CVaR 可以写成

$$\text{CVaR}_{\alpha,t}(Z) = \text{ess inf}_{\eta \in L^\infty(\mathcal{F}_t)} \left\{ \eta + \frac{1}{1-\alpha} \mathbb{E}[(Z - \eta)_+ | \mathcal{F}_t] \right\}. \quad (17.34)$$

这里阈值 η 可以依赖当前历史, 却不能依赖尚未观察的下一步结果。本质下确界忽略当前概率为零的历史差异。有限概率树上, 它等价于在每个当前节点分别应用式 (17.9)。

17.5.3 嵌套风险给出时间一致的评价

令 $C_t \in L^\infty(\mathcal{F}_t)$ 表示时刻 t 已经知道的有界阶段损失。从后向前定义

$$\mathcal{R}_H(C_H) = C_H, \quad (17.35)$$

$$\mathcal{R}_t(C_t, \dots, C_H) = C_t + \rho_t(\mathcal{R}_{t+1}(C_{t+1}, \dots, C_H)). \quad (17.36)$$

这称为**嵌套动态风险** (nested dynamic risk)。当前评价先接受下一时刻对剩余损失的评价, 再用当前条件风险汇总各下一状态。若每个 ρ_t 单调, 则它满足递归意义下的**时间一致性** (time consistency): 对两组从 $t+1$ 开始的损失, 只要下一时刻在每个历史下都认为第一组不比第二组更差, 当前时刻也不会颠倒这一排序。若某项阶段损失 $\tilde{C}_{t+1}$ 要到下一时刻才揭晓, 它属于 $L^\infty(\mathcal{F}_{t+1})$ 。若用 $\tilde{\mathcal{R}}_t$ 表示这种口径下从时刻 t 看到的剩余风险, 相应的一步应写成

$$\tilde{\mathcal{R}}_t = \rho_t(\tilde{C}_{t+1} + \tilde{\mathcal{R}}_{t+1}),$$

不能把 $\tilde{C}_{t+1}$ 作为当前已知量放在 ρ_t 之外。

形式地, 若

$$\mathcal{R}_{t+1}(C_{t+1:H}) \leq \mathcal{R}_{t+1}(C'_{t+1:H}) \quad \text{几乎处处,}$$

单调性立即给出

$$C_t + \rho_t(\mathcal{R}_{t+1}(C_{t+1:H})) \leq C_t + \rho_t(\mathcal{R}_{t+1}(C'_{t+1:H})).$$

证明很短, 因为时间一致性已经被递归结构编码进去。它不说明嵌套 CVaR 等于初始时对总累计损失计算一次静态 CVaR; 前面的两节点例子恰好说明两者会给出不同目标。

在该例中, 若每个节点都使用 $\text{CVaR}_{0.5}$, 节点 B 先把 F 评价为 3.5、把 R 评价为 4, 所以选择 F 。根节点再对“节点 N 为 2、节点 B 为 3.5”计算条件 CVaR, 得到 3.5。嵌套目标选择 F , 而静态总损失 CVaR 选择预先承诺 R 。二者不是同一目标的两种算法实现。

17.5.4 风险 Bellman 递推

在 Markov 状态已经保留条件风险所需信息时, 可把一步条件风险写成依赖状态行动的映射 $\rho_{s,a}$ 。有限时域风险价值满足

$$V_H(s) = c_H(s), \quad (17.37)$$

$$V_t(s) = \min_{a \in \mathcal{A}(s)} \{c_t(s, a) + \rho_{t,s,a}(V_{t+1}(S_{t+1}))\}. \quad (17.38)$$

其中随机变量 $V_{t+1}(S_{t+1})$ 的分布由 $P_t(\cdot | s, a)$ 给出。若 ρ 取条件期望, 式 (17.38) 退化为普通 Bellman 递推; 若取条件 CVaR, 它计算的是逐阶段嵌套 CVaR³。

无限折扣情形定义

$$(T_\rho V)(s) = \min_a \{c(s, a) + \gamma \rho_{s,a}(V(S'))\}. \quad (17.39)$$

假设成本有界, 每个一步风险映射满足单调性、平移等变性和归一化。若 $\|V - W\|_\infty \leq \delta$, 则逐点有

$$W(S') - \delta \leq V(S') \leq W(S') + \delta.$$

单调性与平移等变性给出

$$\rho_{s,a}(W(S')) - \delta \leq \rho_{s,a}(V(S')) \leq \rho_{s,a}(W(S')) + \delta.$$

因此每个一步风险映射都非扩张。这里 V, W 是有限状态上的实际向量, δ 使用普通最大范数, 并且不涉及零测集上的等价类。若改用一般 L^∞ 空间, 还须确认转移核不会读取所选代表在零测集上的任意取值, 不能未经核对便把同一证明逐字搬过去。再使用最小值差的基本不等式,

$$\|T_\rho V - T_\rho W\|_\infty \leq \gamma \|V - W\|_\infty. \quad (17.40)$$

当 $\gamma < 1$ 时, Banach 定理给出唯一有界固定点和价值迭代的几何收敛。

这个压缩证明只回答算子是否有唯一固定点。要把固定点解释为所声明

³ A. Ruszczyński, *Risk-Averse Dynamic Programming for Markov Decision Processes In Mathematical Programming*, 2010, vol. 125, no. 2, pp. 235–261

的动态风险最优值，还须核对三项条件：风险目标是否确实按式 (17.36) 递归；当前状态是否包含风险评价所需的历史信息；允许策略类是否与 Bellman 逐状态选择相容。一个收敛的递推可以稳定地求解错误目标，压缩性不会替代建模核对。

17.5.5 静态 CVaR 的状态增广

若目标是

$$\text{CVaR}_\alpha \left(\sum_{t=0}^H \gamma^t C_t \right),$$

不能一般在原状态上把普通期望替换成一步 CVaR。由式 (17.9)，可先固定阈值 η ，再最小化

$$\eta + \frac{1}{1-\alpha} \mathbb{E} \left[\left(\sum_{t=0}^H \gamma^t C_t - \eta \right)_+ \right].$$

正部函数依赖截至当前已经累计了多少损失以及还剩多少阈值。把累计损失或剩余阈值加入状态后，可以对固定 η 建立动态规划，最后再优化 η 。这种状态增广保留的是静态总损失 CVaR；直接改用嵌套条件 CVaR 则改变了目标。

增广状态可能连续，计算规模也会增大。若阶段损失无界，还需保证正部期望有限；若策略可以依赖累计损失，允许策略类也随状态增广而扩大。所谓“CVaR 可以动态规划”必须同时说明采用的是哪种表示、优化哪种策略，以及递推对应静态还是嵌套风险。

17.5.6 风险包络与矩形结构

无罚项的概率包络需要比单调和平移等变更更强的条件。先固定一个具有 m 个结果的有限空间，把一步风险写成 $\rho: \mathbb{R}^m \rightarrow \mathbb{R}$ 。若 ρ 归一化，并同时满足单调性、平移等变性、正齐次性和次可加性，它就是相干风险。正齐次与次可加使 ρ 成为有限凸的次线性函数。定义

$$\mathcal{Q} = \{ \mathbf{q} \in \mathbb{R}^m : \langle \mathbf{q}, \mathbf{z} \rangle \leq \rho(\mathbf{z}) \text{ 对所有 } \mathbf{z} \in \mathbb{R}^m \}.$$

有限维次线性函数的支撑表示给出

$$\rho(\mathbf{z}) = \max_{\mathbf{q} \in \mathcal{Q}} \langle \mathbf{q}, \mathbf{z} \rangle.$$

具体地说， ρ 的凸共轭在 $\mathcal{Q}$ 上为零、在其外为无穷，Fenchel–Moreau 对偶便得到上式。平移等变性应用于 $\mathbf{z} + r\mathbf{1}$ 迫使每个 $\mathbf{q} \in \mathcal{Q}$ 满足 $\langle \mathbf{q}, \mathbf{1} \rangle = 1$ ；单调性再迫使 $q_i \geq 0$ 。因此 $\mathcal{Q}$ 是概率单纯形中的非空闭凸集，有限维紧致性

保证最大值达到。

若风险仅为归一化、单调、平移等变的凸风险，正齐次可能不成立。此时一般对偶形式为

$$\rho(\mathbf{z}) = \sup_{\mathbf{q} \in \Delta_m} \{\langle \mathbf{q}, \mathbf{z} \rangle - \beta(\mathbf{q})\},$$

其中 $\Delta_m = \{\mathbf{q} \in \mathbb{R}_+^m : \langle \mathbf{q}, \mathbf{1} \rangle = 1\}$ 是概率单纯形， β 是允许取无穷值的凸罚函数；不能无条件删去罚项并称为最坏期望。

回到 Markov 过程，若每个状态行动处都使用相干的一步条件风险映射，便可写成风险包络中的最坏条件期望：

$$\rho_{s,a}(V(S')) = \sup_{q \in Q(s,a)} \sum_{s'} q(s' | s, a) V(s'). \quad (17.41)$$

条件 CVaR 对应对名义转移概率作有上界的密度重加权。把式 (17.41) 代入式 (17.39)，得到

$$(T_\rho V)(s) = \min_a \sup_{q \in Q(s,a)} \left\{ c(s, a) + \gamma \sum_{s'} q(s' | s, a) V(s') \right\}.$$

它看起来像鲁棒 MDP，但递推还依赖不确定集合能否按历史逐步选择。

若每个状态行动处的条件分布可以独立从 $Q(s, a)$ 选择，并且后续选择只受当前历史约束，这种乘积式结构称为 **矩形性** (rectangularity)。矩形性允许把整条路径上的最坏分布拆成逐节点最坏条件分布，风险包络才与 Bellman 递推相容。

若不确定性在多个时刻之间共享同一个未知参数，允许的路径分布通常是耦合的。例如一个固定但未知的故障率必须在全程保持相同，不能在每个状态分别挑选最坏故障率。逐节点取上确界会允许一个并不存在的对手沿历史改变参数，相当于把原集合扩张成矩形包络，结果可能更保守，也可能定义完全不同的最坏模型问题。此时应保留共享参数的信念或把它加入状态，而不是把非矩形集合直接塞入普通 Bellman 算子。

动态风险的边界由此清楚起来。单调性和平移等变性给出一步非扩张，折扣产生压缩；递归嵌套给出时间一致性，状态充分性保证当前节点拥有正确条件信息；风险包络若要解释为逐步鲁棒选择，还需矩形结构。任一条件缺失，形式相似的递推都可能不再评价原先声明的随机损失。

17.6 本章小结

概率预测只有与行动和损失结合后，才能回答应该做什么。条件风险把后验分布中的各项结果按损失加权，Bayes 规则再选择条件风险最小的行动。错误代价、拒答成本和总体预算会改变阈值，即使概率输出完全相同也可能产生不同的合理决策；随机化只有在并列或耦合约束下才提供额外作

用。

风险准则规定怎样汇总随机损失。期望控制平均结果，方差同时计算好坏两侧的波动，VaR 给出分位切点，CVaR 则通过分位点优化平均最坏尾部。离散分布的分位点可能承载正概率，此时必须从边界原子中补足尾部质量。CVaR 的风险包络说明它等价于一类受限重加权下的最坏期望；机会约束、一般最坏模型与分布鲁棒目标仍分别控制违规概率、模型集合和分布集合，不能仅凭“保守”二字合并。

行动影响未来状态后，策略价值由条件期望和状态转移共同决定。有限域 Bellman 递推可由逆向归纳证明，折扣 Bellman 算子则在有界函数的上确界范数下成为压缩。价值端的 Bellman 不等式与流量端的非负占用度量构成一对线性规划；初始分布、折扣归一化和流量守恒使对偶变量具有真实访问频率的含义。平均成本与连续状态问题需要额外条件，不能从有限折扣结论直接外推。

信息之所以有价值，不是因为它必然减少某种抽象不确定性，而是因为观察后可以改变行动。EVSI 比较观察前后的最优 Bayes 风险，多臂例子中的探索收益来自当前试验改善下一轮选择。自适应取得数据同时改变统计证据的条件，仍需序贯集中和可预测设计支持误差结论。

静态总损失 CVaR 可能在到达未来分支后发生偏好反转。条件风险映射按当前信息评价未来，递归嵌套由单调性保持跨时排序，从而建立时间一致的动态风险。对单调且平移等变的一步风险映射，折扣风险 Bellman 算子仍是压缩；但固定点要对应正确目标，还需状态充分、策略类相容和正确的递归定义。静态 CVaR 通常需要累计损失或阈值的状态增广，风险包络的逐步鲁棒解释还需要矩形性。下一章将在这些价值对象上加入受控动力学，推导线性二次控制、安全反馈与连续时间最优性条件；随后的博弈论章则进一步允许其他参与者也选择策略。

控制理论

第 16 章研究了输入给定以后，状态怎样演化、扰动怎样传播，以及有限观测能够提供多少状态信息。第 17 章又为跨时刻的行动后果建立了价值递推。还缺的一步是把输入本身变成待选择的对象：系统每到一个状态，都要依据当前可用信息决定下一次作用。这样形成的 **反馈**（feedback）会改变后续状态，后续状态又会改变未来的反馈。

这一步不能只靠写出一个优化目标。某个不稳定方向可能根本不受输入影响，某个影响决策的状态方向也可能无法从观测辨认；即使期望成本达到最小，轨迹仍可能穿过不可接受的区域。控制理论分别询问这些问题：哪些动态模式能够被输入改变，哪些模式能够被输出识别，怎样在长期稳定的前提下优化成本，以及怎样让每条允许轨迹都留在安全集合内。

本章先在线性状态空间中建立可控、可稳定、可观测和可检测四个结构条件。它们为线性二次调节和稳态滤波说明“解为什么存在且能稳定系统”。随后，我们从有限时域价值递推完整推出 Riccati 递推，并将成本最优与安全集合保持分开。最后把离散时间的 Bellman 原理缩到一个短时间段内，得到连续时间的 Hamilton–Jacobi–Bellman 方程。四节讨论的是同一个受控动态的不同要求；一个要求成立，不能替代其余要求。

18.1 反馈与系统结构

18.1.1 反馈把输入变成状态的函数

考虑离散时间线性时不变系统

$$\begin{aligned} \mathbf{x}_{t+1} &= \mathbf{A}\mathbf{x}_t + \mathbf{B}\mathbf{u}_t, \\ \mathbf{y}_t &= \mathbf{C}\mathbf{x}_t, \end{aligned} \tag{18.1}$$

其中 $\mathbf{x}_t \in \mathbb{R}^n$ 是状态， $\mathbf{u}_t \in \mathbb{R}^m$ 是控制输入， $\mathbf{y}_t \in \mathbb{R}^p$ 是观测。矩阵维度相应为 $\mathbf{A} \in \mathbb{R}^{n \times n}$ 、 $\mathbf{B} \in \mathbb{R}^{n \times m}$ 和 $\mathbf{C} \in \mathbb{R}^{p \times n}$ 。这里明确令直接传递矩阵为零，因此时刻 t 先由 $\mathbf{x}_t$ 产生 $\mathbf{y}_t$ ，控制器再计算 $\mathbf{u}_t$ 。若保留 $\mathbf{y}_t = \mathbf{C}\mathbf{x}_t + \mathbf{D}\mathbf{u}_t$ 并允许 $\mathbf{u}_t$ 依赖当前 $\mathbf{y}_t$ ，两式会形成需要另行求解适定性的代数环；另一

种无环约定是只让控制使用截至 $t-1$ 的观测。

在给定输入的动力系统中, $\mathbf{u}_0, \mathbf{u}_1, \dots$ 可以事先指定, 这称为**开环控制**: 输入不根据运行中实际出现的状态修正。控制问题则允许输入依据当前信息改变。例如, 状态能够直接取得时,

$$\mathbf{u}_t = \kappa_t(\mathbf{x}_t)$$

是状态反馈; 只有观测历史可用时,

$$\mathbf{u}_t = \mu_t(\mathbf{y}_0, \dots, \mathbf{y}_t; \mathbf{u}_0, \dots, \mathbf{u}_{t-1})$$

才是可实现的输出反馈, 其中空的初始控制历史按空序列处理。由于本节采用零直接传递, 当前观测 $\mathbf{y}_t$ 不含尚未计算的 $\mathbf{u}_t$ 。写出依赖真实状态的公式, 不等于传感器已经提供了该状态。

反馈把原系统与控制律合成一个新的闭环动力系统, 因而还要重新检查解是否存在且唯一。离散时间递推只要每一步的反馈有定义, 就能逐步生成轨迹; 连续时间系统则通常要求动态与反馈满足局部 Lipschitz 等适定性条件。若反馈在切换面不连续, 必须改用适合不连续右端的解概念, 不能只凭形式上的闭环方程断言轨迹唯一。

最简单的线性状态反馈取

$$\mathbf{u}_t = -\mathbf{K}\mathbf{x}_t, \quad \mathbf{x}_{t+1} = (\mathbf{A} - \mathbf{B}\mathbf{K})\mathbf{x}_t. \quad (18.2)$$

因此闭环离散系统渐近稳定, 当且仅当 $\mathbf{A} - \mathbf{B}\mathbf{K}$ 的全部特征值都严格位于单位圆内。这里的负号只是约定; 若写 $\mathbf{u}_t = \mathbf{F}\mathbf{x}_t$, 对应闭环矩阵就是 $\mathbf{A} + \mathbf{B}\mathbf{F}$ 。

反馈能否把不稳定特征值移入单位圆, 取决于输入是否真正作用到相应状态方向。这不是优化算法精度问题, 而是矩阵对 $(\mathbf{A}, \mathbf{B})$ 本身的结构性质。

18.1.2 可控性刻画有限时间内能够到达的状态

把式 (18.1) 连续展开 N 步, 可得

$$\mathbf{x}_N = \mathbf{A}^N \mathbf{x}_0 + \sum_{t=0}^{N-1} \mathbf{A}^{N-1-t} \mathbf{B} \mathbf{u}_t. \quad (18.3)$$

固定初态后, 终态中能被控制改变的部分属于

$$\text{span}\{\mathbf{B}, \mathbf{A}\mathbf{B}, \dots, \mathbf{A}^{N-1}\mathbf{B}\}$$

的列空间。这些列依次表示一次输入经过零步、一步直至 $N-1$ 步传播后能够产生的状态方向。

定义 18.1 可控性 若对任意初态 $\mathbf{x}_0$ 和任意目标状态 $\mathbf{x}_f$ ，都存在有限时刻 N 及输入序列 $\mathbf{u}_0, \dots, \mathbf{u}_{N-1}$ ，使 $\mathbf{x}_N = \mathbf{x}_f$ ，则称 $(\mathbf{A}, \mathbf{B})$ 可控。

对线性时不变系统，“从任意初态到任意终态”与“从零到任意终态”等价：式 (18.3) 对输入线性，自由响应 $\mathbf{A}^N \mathbf{x}_0$ 可以移到目标一侧。这两种性质都蕴含任意初态可以在有限时间驱动到零，但反向一般不成立。后一种较弱的性质称为**零可控性**。例如，标量系统 $A=0, B=0$ 会使任意初态在一步后自然变为零，却无法从零到达非零状态；当 $\mathbf{A}$ 可逆时，零可控性才可反推出这里定义的可控性。

定理 18.2 Kalman 可控性秩判据 定义可控性矩阵

$$\mathcal{C}(\mathbf{A}, \mathbf{B}) = [\mathbf{B} \quad \mathbf{A}\mathbf{B} \quad \dots \quad \mathbf{A}^{n-1}\mathbf{B}]. \quad (18.4)$$

系统 $(\mathbf{A}, \mathbf{B})$ 可控，当且仅当

$$\text{rank } \mathcal{C}(\mathbf{A}, \mathbf{B}) = n.$$

证明. 先取 $N = n$ 。把输入按逆时间顺序堆成向量，式 (18.3) 中的受控部分可以写成

$$\mathcal{C}(\mathbf{A}, \mathbf{B}) \begin{bmatrix} \mathbf{u}_{n-1} \\ \mathbf{u}_{n-2} \\ \vdots \\ \mathbf{u}_0 \end{bmatrix}.$$

若可控性矩阵满行秩，它的列张成 $\mathbb{R}^n$ ，所以对任意 $\mathbf{x}_f - \mathbf{A}^n \mathbf{x}_0$ 都能找到输入，系统可控。

反过来，若该矩阵秩小于 n ，其列空间是 $\mathbb{R}^n$ 的真子空间。Cayley-Hamilton 定理说明 $\mathbf{A}^n$ 可写成 $\mathbf{I}, \mathbf{A}, \dots, \mathbf{A}^{n-1}$ 的线性组合；继续乘 $\mathbf{A}$ 可知，每个 $\mathbf{A}^k \mathbf{B}$ ($k \geq n$) 仍落在 $\mathcal{C}(\mathbf{A}, \mathbf{B})$ 的列空间中。延长时域不会增加新的可达方向，因而从零出发无法到达该列空间外的状态，系统不可控。 ■

最小的算例是标量积分系统 $x_{t+1} = x_t + u_t$ 。给定 x_0 与目标 x_f ，一步取 $u_0 = x_f - x_0$ 即可到达，因而其可控性矩阵 $[1]$ 满秩。若改成二维系统

$$\mathbf{A} = \begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix}, \quad \mathbf{B} = \begin{bmatrix} 0 \\ 1 \end{bmatrix},$$

则当前输入先改变第二个坐标，经过一次状态传播后再影响第一个坐标。

此时

$$\begin{bmatrix} \mathbf{B} & \mathbf{AB} \end{bmatrix} = \begin{bmatrix} 0 & 1 \\ 1 & 1 \end{bmatrix}$$

满秩, 两个坐标都可达。相反, 若 $\mathbf{A} = \mathbf{I}$ 而 $\mathbf{B} = (1, 0)^\top$, 输入无论作用多久都只能改变第一个坐标; 延长时域不会补出缺失方向。

连续时间线性系统 $\dot{\mathbf{x}} = \mathbf{Ax} + \mathbf{Bu}$ 具有相同问题, 但输入通过积分累积。由状态转移公式,

$$\mathbf{x}(T) = e^{\mathbf{AT}}\mathbf{x}_0 + \int_0^T e^{\mathbf{A}(T-s)}\mathbf{B}\mathbf{u}(s) \, ds.$$

定义时域 $T > 0$ 上的**可控 Gram 矩阵**

$$\mathbf{W}_c(T) = \int_0^T e^{\mathbf{As}}\mathbf{B}\mathbf{B}^\top e^{\mathbf{A}^\top s} \, ds. \quad (18.5)$$

连续线性系统在 $[0, T]$ 上可控, 当且仅当 $\mathbf{W}_c(T) > \mathbf{0}$ 。事实上, 对任意 $\mathbf{q} \in \mathbb{R}^n$,

$$\mathbf{q}^\top \mathbf{W}_c(T) \mathbf{q} = \int_0^T \|\mathbf{B}^\top e^{\mathbf{A}^\top s} \mathbf{q}\|_2^2 \, ds.$$

若 Gram 矩阵奇异, 就存在非零 $\mathbf{q}$ 使被积函数恒为零, 该方向与所有受控终态增量正交, 因而不可达。若 Gram 矩阵正定, 则对所需增量 $\mathbf{d} = \mathbf{x}_f - e^{\mathbf{AT}}\mathbf{x}_0$ 取

$$\mathbf{u}(s) = \mathbf{B}^\top e^{\mathbf{A}^\top(T-s)} \mathbf{W}_c(T)^{-1} \mathbf{d},$$

代入状态转移公式便得到终态增量 $\mathbf{d}$ 。这个 Gram 判据依赖线性时不变结构; 一般非线性系统即使在一点把 Jacobian 矩阵代入, 也只能得到局部线性化信息, 不能据此推出全局可控。

秩判据回答“整个状态空间是否可达”, 但有时我们只需判断某个动态模式是否受控。在复数域上考察 $\mathbf{A}$ 的左特征向量会得到更直接的判据。

定理 18.3 Popov-Belevitch-Hautus(PBH)可控性判据 矩阵对 $(\mathbf{A}, \mathbf{B})$ 可控, 当且仅当对 $\mathbf{A}$ 的每个复特征值 λ 都有

$$\text{rank} \begin{bmatrix} \lambda \mathbf{I} - \mathbf{A} & \mathbf{B} \end{bmatrix} = n. \quad (18.6)$$

等价地, 不存在非零左特征向量 $\mathbf{q}^*$ 满足 $\mathbf{q}^* \mathbf{A} = \lambda \mathbf{q}^*$ 且 $\mathbf{q}^* \mathbf{B} = \mathbf{0}$ 。

证明. 若存在这样的 $\mathbf{q}^*$, 则对每个 $k \geq 0$,

$$\mathbf{q}^* \mathbf{A}^k \mathbf{B} = \lambda^k \mathbf{q}^* \mathbf{B} = \mathbf{0}.$$

所以可控性矩阵的每一列都位于 $\mathbf{q}^*$ 的零空间, 不可能满行秩。

反向可用 $\mathbf{A}$ 不变子空间说明。若可控性矩阵不满秩，它的列空间 $\mathcal{R}$ 是一个真子空间，并且 $\mathbf{A}\mathcal{R} \subseteq \mathcal{R}$ 。于是正交补 $\mathcal{R}^\perp$ 在 $\mathbf{A}^*$ 下不变。复数域上的非零有限维不变子空间包含 $\mathbf{A}^*$ 的一个特征向量 $\mathbf{q}$ 。它正交于 $\mathcal{R}$ ，特别有 $\mathbf{q}^*\mathbf{B} = \mathbf{0}$ ，从而式 (18.6) 在相应特征值处不满秩。 ■

18.1.3 可稳定性只要求危险模式可控

完全可控时，极点配置定理允许通过状态反馈配置闭环特征值；稳定系统并不总需要这么强的条件。若某个不可控模式本身已经衰减，就没有必要通过输入移动它。

定义 18.4 可稳定性 若存在矩阵 $\mathbf{K}$ ，使 $\mathbf{A} - \mathbf{BK}$ 的全部特征值严格位于单位圆内，则称离散时间矩阵对 $(\mathbf{A}, \mathbf{B})$ 可稳定。

这个结论可以由 Kalman 可控分解看清。令 $\mathcal{R}$ 为可控性矩阵的列空间，并选择以 $\mathcal{R}$ 的一组基为前若干列的可逆矩阵 $\mathbf{T}$ 。由于 $\mathbf{A}\mathcal{R} \subseteq \mathcal{R}$ 且 $\text{col}(\mathbf{B}) \subseteq \mathcal{R}$ ，在坐标 $\mathbf{z} = \mathbf{T}^{-1}\mathbf{x}$ 下有

$$\mathbf{T}^{-1}\mathbf{AT} = \begin{bmatrix} \mathbf{A}_c & \mathbf{A}_{12} \\ \mathbf{0} & \mathbf{A}_{uc} \end{bmatrix}, \quad \mathbf{T}^{-1}\mathbf{B} = \begin{bmatrix} \mathbf{B}_c \\ \mathbf{0} \end{bmatrix},$$

其中 $(\mathbf{A}_c, \mathbf{B}_c)$ 可控。把 $\mathbf{KT}$ 分块写成 $[\mathbf{K}_c \ \mathbf{K}_{uc}]$ 后，闭环矩阵在同一坐标下变为

$$\begin{bmatrix} \mathbf{A}_c - \mathbf{B}_c\mathbf{K}_c & \mathbf{A}_{12} - \mathbf{B}_c\mathbf{K}_{uc} \\ \mathbf{0} & \mathbf{A}_{uc} \end{bmatrix}.$$

反馈可以通过 $\mathbf{K}_c$ 配置可控块的特征值，却不能改变不可控块 $\mathbf{A}_{uc}$ 的特征值。因此，存在稳定化反馈当且仅当不可控块本身稳定。PBH 矩阵在特征值 λ 处不满秩，恰好表示 λ 属于这个不可控块；所以只需排除不稳定和临界的不可控模式：

$$\text{rank} \begin{bmatrix} \lambda \mathbf{I} - \mathbf{A} & \mathbf{B} \end{bmatrix} = n \quad \text{对每个满足 } |\lambda| \geq 1 \text{ 的 } \lambda \in \sigma(\mathbf{A}). \quad (18.7)$$

可控必然推出可稳定，反向并不成立。这个差别在无限时域调节中很重要：已经稳定但无法控制的模式可以留在原处，无法控制的不稳定模式却会使任何线性反馈都失败。

示例 18.5 不可控但可稳定的系统 令

$$\mathbf{A} = \begin{bmatrix} 1.2 & 0 \\ 0 & 0.5 \end{bmatrix}, \quad \mathbf{B} = \begin{bmatrix} 1 \\ 0 \end{bmatrix}.$$

可控性矩阵

$$\begin{bmatrix} B & AB \end{bmatrix} = \begin{bmatrix} 1 & 1.2 \\ 0 & 0 \end{bmatrix}$$

只有秩 1，第二个模式不可控。但它的特征值为 0.5，已经位于单位圆内。取 $K = (1, 0)$ ，闭环特征值变成 0.2 和 0.5，所以该系统可稳定。若交换 B 的两个分量，使输入只能作用到 0.5 模式，则 1.2 模式不可控，系统便不可稳定。

18.1.4 可观测性与可检测性刻画信息条件

控制器若只能看见输出，就要先问不同初态能否由输出序列区分。暂取输入为零；已知输入对输出的贡献可以计算并扣除，不改变以下结构判据。连续观察 n 个时刻得到

$$\begin{bmatrix} y_0 \\ y_1 \\ \vdots \\ y_{n-1} \end{bmatrix} = \underbrace{\begin{bmatrix} C \\ CA \\ \vdots \\ CA^{n-1} \end{bmatrix}}_{\mathcal{O}(C,A)} x_0. \quad (18.8)$$

定义 18.6 可观测性与可检测性 若式 (18.8) 中的观测矩阵 $\mathcal{O}(C, A)$ 满列秩，则称 (C, A) 可观测。若存在矩阵 L 使 $A - LC$ 的全部特征值严格位于单位圆内，则称 (C, A) 可检测。

可观测意味着有限输出序列能够唯一确定任意初态。这个秩条件也可以从“输出能否区分两个初态”直接证明。若 $\mathcal{O}$ 满列秩，则线性方程 (18.8) 至多有一个 x_0 ，所以输出序列唯一确定初态。反之，若 $\mathcal{O}$ 不满列秩，就存在非零 v 满足 $\mathcal{O}v = 0$ ；初态 x_0 与 $x_0 + v$ 在前 n 个时刻产生相同输出。Cayley-Hamilton 定理又使所有 $CA^k v$ ($k \geq n$) 都是前 n 项的线性组合，所以继续观察也无法区分这两个初态。

可检测只要求所有无法从输出辨认的模式自行稳定；不可见但会衰减的状态不会阻止估计误差趋于零。二者的 PBH 判据分别为

$$\text{rank} \begin{bmatrix} \lambda I - A \\ C \end{bmatrix} = n \quad \text{对每个 } \lambda \in \sigma(A), \quad (18.9)$$

$$\text{rank} \begin{bmatrix} \lambda I - A \\ C \end{bmatrix} = n \quad \text{对每个 } |\lambda| \geq 1. \quad (18.10)$$

把 A 换成 $A^\top$ 、把 B 换成 $C^\top$ ，可控性矩阵的转置正是观测矩阵。对偶矩阵

对 $(A^\top, C^\top)$ 应用上述 Kalman 分解, 可知反馈无法移动它的不可控块, 而该块正对应原系统的不可观测模式。又因为

$$A^\top - C^\top L^\top = (A - LC)^\top,$$

两侧具有相同特征值, 所以式 (18.10) 既是必要条件也是充分条件: 不可观测块稳定时, 可以配置其余观测器误差模式; 不可观测块含危险特征值时, 任何 L 都无法消除它。这就是可控与可观测、可稳定与可检测之间的线性代数对偶。

连续时间版本只改变“危险模式”的稳定区域。对 $\dot{x} = Ax + Bu$, 可稳定性要求

$$\text{rank} \begin{bmatrix} \lambda I - A & B \end{bmatrix} = n \quad \text{对每个满足 } \text{Re } \lambda \geq 0 \text{ 的 } \lambda \in \sigma(A);$$

对输出 $y = Cx$, 可检测性要求相应的纵向 PBH 矩阵满列秩。分解与对偶论证和离散情形相同, 只把单位圆外替换为闭右半平面。该接口将在连续时间 Riccati 稳态条件中使用。

继续使用示例 18.5 中的 A 。若 $C = (1, 0)$, 不稳定的 1.2 模式可以观测, 稳定的 0.5 模式不可观测; 系统不可观测但可检测。若改成 $C = (0, 1)$, 输出完全看不到 1.2 模式, 估计误差中的该分量会增长, 系统不可检测。

18.1.5 观测器与控制器可以在条件满足时分开设计

状态不可直接取得时, 可以用 Luenberger **观测器** 根据模型、输入和输出更新估计:

$$\hat{x}_{t+1} = A\hat{x}_t + Bu_t + L(y_t - C\hat{x}_t). \quad (18.11)$$

令估计误差 $e_t = x_t - \hat{x}_t$, 直接相减得到

$$e_{t+1} = (A - LC)e_t.$$

因此可检测性正是选择 L 使误差渐近消失所需的结构条件。

将状态反馈改为 $u_t = -K\hat{x}_t$ 后, 用 x_t 和 e_t 作为联合状态可得

$$\begin{bmatrix} x_{t+1} \\ e_{t+1} \end{bmatrix} = \begin{bmatrix} A - BK & BK \\ 0 & A - LC \end{bmatrix} \begin{bmatrix} x_t \\ e_t \end{bmatrix}. \quad (18.12)$$

该矩阵是分块上三角矩阵, 其特征值是两个对角块特征值的并集。因此, 只要 (A, B) 可稳定且 (C, A) 可检测, 就能分别选择 K 和 L , 使整个确定性线性闭环稳定。这一 **分离原理** 并不表示估计与控制在所有问题中都互不影响; 非线性、约束、模型误差或风险敏感目标可能破坏这种简单分离。

18.2 线性二次控制与 Riccati 方程

18.2.1 有限时域价值保持二次形式

结构条件说明稳定反馈是否可能存在，却没有选择具体反馈。现在为状态偏离和控制用力分别计价。考虑有限时域随机线性系统

$$\mathbf{x}_{t+1} = \mathbf{A}\mathbf{x}_t + \mathbf{B}\mathbf{u}_t + \mathbf{w}_t, \quad t = 0, \dots, T-1, \quad (18.13)$$

以及成本

$$J = \mathbb{E} \left[\mathbf{x}_T^\top \mathbf{Q}_T \mathbf{x}_T + \sum_{t=0}^{T-1} (\mathbf{x}_t^\top \mathbf{Q} \mathbf{x}_t + \mathbf{u}_t^\top \mathbf{R} \mathbf{u}_t) \right]. \quad (18.14)$$

这里 $\mathbf{Q}, \mathbf{Q}_T \in \mathbb{R}^{n \times n}$ 且 $\mathbf{Q}, \mathbf{Q}_T \geq \mathbf{0}$, $\mathbf{R} \in \mathbb{R}^{m \times m}$ 且 $\mathbf{R} > \mathbf{0}$ 。半正定状态代价允许某些状态方向不直接计价；正定控制代价保证每一步关于 $\mathbf{u}_t$ 的二次目标严格凸。

由线性动态和二次成本构成的这类调节问题称为**线性二次调节** (linear-quadratic regulation, LQR)。

先假设状态完全可见，且 $\mathbf{w}_t$ 相互独立、均值为零、协方差为 Σ_w ，并与当前状态和动作独立。令 $\mathcal{F}_t = \sigma(\mathbf{x}_0, \dots, \mathbf{x}_t)$ 表示截至时刻 t 可用的状态信息，并用 Π_t 表示从 t 到 $T-1$ 的允许反馈策略；对任意 $\pi \in \Pi_t$ ，控制 $\mathbf{u}_\tau$ 必须对 $\mathcal{F}_\tau$ 可测，不能预先利用未来噪声。定义从时刻 t 起的最优剩余成本

$$V_t(\mathbf{x}) = \inf_{\pi \in \Pi_t} \mathbb{E} \left[\mathbf{x}_T^\top \mathbf{Q}_T \mathbf{x}_T + \sum_{\tau=t}^{T-1} (\mathbf{x}_\tau^\top \mathbf{Q} \mathbf{x}_\tau + \mathbf{u}_\tau^\top \mathbf{R} \mathbf{u}_\tau) \middle| \mathbf{x}_t = \mathbf{x} \right].$$

这里的下确界对适应当前状态信息的策略取，而不是对事先固定的开环控制序列取。终端价值为 $V_T(\mathbf{x}) = \mathbf{x}^\top \mathbf{Q}_T \mathbf{x}$ ¹。第 17 章的 Bellman 原理给出

$$V_t(\mathbf{x}) = \min_{\mathbf{u}} \{ \mathbf{x}^\top \mathbf{Q} \mathbf{x} + \mathbf{u}^\top \mathbf{R} \mathbf{u} + \mathbb{E} [V_{t+1}(\mathbf{A}\mathbf{x} + \mathbf{B}\mathbf{u} + \mathbf{w}_t)] \}. \quad (18.15)$$

¹ B. D. O. Anderson, J. B. Moore, *Optimal Control: Linear Quadratic Methods*, Dover Publications, 2007

定理 18.7 有限时域 LQR 与 Riccati 递推 在上述条件下，最优价值具有形式

$$V_t(\mathbf{x}) = \mathbf{x}^\top \mathbf{P}_t \mathbf{x} + c_t,$$

其中 $\mathbf{P}_T = \mathbf{Q}_T$ 、 $c_T = 0$ 。令

$$\begin{aligned} \mathbf{S}_t &= \mathbf{R} + \mathbf{B}^\top \mathbf{P}_{t+1} \mathbf{B}, \\ \mathbf{K}_t &= \mathbf{S}_t^{-1} \mathbf{B}^\top \mathbf{P}_{t+1} \mathbf{A}. \end{aligned} \quad (18.16)$$

则最优控制为

$$\mathbf{u}_t^* = -\mathbf{K}_t \mathbf{x}_t,$$

而 P_t 满足离散 Riccati 递推

$$P_t = Q + A^\top P_{t+1} A - A^\top P_{t+1} B S_t^{-1} B^\top P_{t+1} A. \quad (18.17)$$

噪声只进入常数项

$$c_t = c_{t+1} + \text{tr}(P_{t+1} \Sigma_w). \quad (18.18)$$

证明. 采用反向归纳. 终端时刻的结论由 $P_T = Q_T, c_T = 0$ 成立. 假设 $t+1$ 时刻价值已经具有所述形式. 记

$$z = Ax + Bu.$$

零均值和独立性给出

$$\begin{aligned} \mathbb{E}[V_{t+1}(z + w_t)] &= \mathbb{E}[(z + w_t)^\top P_{t+1} (z + w_t)] + c_{t+1} \\ &= z^\top P_{t+1} z + \text{tr}(P_{t+1} \Sigma_w) + c_{t+1}. \end{aligned}$$

交叉项的条件期望为零. 将 z 展开, 并只收集与控制有关的项, Bellman 目标成为

$$\begin{aligned} &x^\top (Q + A^\top P_{t+1} A) x + 2u^\top B^\top P_{t+1} A x \\ &+ u^\top (R + B^\top P_{t+1} B) u + \text{tr}(P_{t+1} \Sigma_w) + c_{t+1}. \end{aligned}$$

因为 $R > 0$ 且 $P_{t+1} \geq 0$, $S_t > 0$. 以式 (18.16) 中的 K_t 配方,

$$\begin{aligned} &u^\top S_t u + 2u^\top B^\top P_{t+1} A x \\ &= (u + K_t x)^\top S_t (u + K_t x) - x^\top K_t^\top S_t K_t x. \end{aligned}$$

第一项非负, 并且仅在 $u = -K_t x$ 时为零. 把剩余二次项合并, 恰好得到式 (18.17); 与状态无关的项给出式 (18.18). Riccati 右端保持半正定, 于是归纳可以继续到 $t = 0$. ■

该证明同时解释了“二次价值族在 Bellman 备份下封闭”的含义: 线性动态把状态与动作送入二次型, 最小化动作后仍留下状态的二次型. 一般非线性动态或非二次代价不具有这个闭合关系, 不能仅把矩阵换成 Jacobian 矩阵就得到精确 LQR.

噪声不改变反馈增益也有明确边界. 这里用到了噪声条件均值为零、与当前决策独立, 以及风险中性期望成本. 若噪声均值非零, 价值函数一般还需要线性项, 最优控制会出现仿射偏置; 若噪声分布受动作影响、与状态相关, 或目标惩罚尾部风险, 噪声可能直接改变反馈律.

18.2.2 一个标量系统可以核对全部配方

取无噪声标量系统

$$x_{t+1} = 1.2x_t + u_t, \quad Q = R = 1.$$

若下一步价值系数为 P_{t+1} , 则

$$S_t = 1 + P_{t+1}, \quad K_t = \frac{1.2P_{t+1}}{1 + P_{t+1}},$$

并且

$$P_t = 1 + 1.44P_{t+1} - \frac{1.44P_{t+1}^2}{1 + P_{t+1}} = 1 + \frac{1.44P_{t+1}}{1 + P_{t+1}}.$$

当终端代价 $P_T = 0$ 时, 倒数第一步有 $P_{T-1} = 1$, $K_{T-1} = 0$; 最后一个动作之后没有状态代价, 所以此时不用力。再向前一步得到 $P_{T-2} = 1.72$ 和 $K_{T-2} = 0.6$ 。时域变长后, 远离终端的增益逐渐接近稳态值。

18.2.3 无限时域需要稳定化 Riccati 解

本小节切换到确定性系统, 即在式 (18.13) 中令 $w_t = \mathbf{0}$ 。对时不变、无折扣的无限时域问题, 考虑总成本

$$J_\infty = \sum_{t=0}^{\infty} (\mathbf{x}_t^\top \mathbf{Q} \mathbf{x}_t + \mathbf{u}_t^\top \mathbf{R} \mathbf{u}_t).$$

该级数并非对任意控制都有限; 稳定化条件用于保证最优反馈下的状态和控制充分衰减。希望 $\mathbf{P}_t$ 和 $\mathbf{K}_t$ 不再随时间变化。将 $\mathbf{P}_{t+1} = \mathbf{P}_t = \mathbf{P}$ 代入式 (18.17), 得到 **离散代数 Riccati 方程** (discrete algebraic Riccati equation, DARE):

$$\mathbf{P} = \mathbf{Q} + \mathbf{A}^\top \mathbf{P} \mathbf{A} - \mathbf{A}^\top \mathbf{P} \mathbf{B} (\mathbf{R} + \mathbf{B}^\top \mathbf{P} \mathbf{B})^{-1} \mathbf{B}^\top \mathbf{P} \mathbf{A}. \quad (18.19)$$

一个满足代数等式的矩阵未必就是所需解。控制所需的是 **稳定化解**: 除满足 $\mathbf{P} \geq \mathbf{0}$ 外, 它产生的

$$\mathbf{K} = (\mathbf{R} + \mathbf{B}^\top \mathbf{P} \mathbf{B})^{-1} \mathbf{B}^\top \mathbf{P} \mathbf{A}$$

还要使 $\mathbf{A} - \mathbf{B} \mathbf{K}$ 稳定。

定理 18.8 无限时域 LQR 的稳定化解 设 $\mathbf{Q} \geq \mathbf{0}$ 、 $\mathbf{R} > \mathbf{0}$ 。若 $(\mathbf{A}, \mathbf{B})$ 可稳定, 且 $(\mathbf{Q}^{1/2}, \mathbf{A})$ 可检测, 则式 (18.19) 存在唯一的半正定稳定化解 $\mathbf{P}$ 。由该解得到的线性反馈使闭环渐近稳定, 并给出无限时域二次成本的最优值 $V(\mathbf{x}) = \mathbf{x}^\top \mathbf{P} \mathbf{x}$ 。

证明. 这里给出决定条件作用的证明主线。对终端矩阵取 $\mathbf{P}_N = \mathbf{0}$, 从长度

N 的有限时域问题反向递推, 并记初始时刻矩阵为 $\mathbf{P}^{(N)}$ 。增加一个非负阶段成本不会降低最优成本, 所以

$$\mathbf{0} \leq \mathbf{P}^{(N)} \leq \mathbf{P}^{(N+1)}.$$

可稳定性保证存在某个 $\bar{\mathbf{K}}$ 使 $\mathbf{A} - \mathbf{B}\bar{\mathbf{K}}$ 稳定。始终采用这一反馈所得无限时域成本有限, 因此它为所有有限时域最优成本提供统一二次上界。单调且有上界的半正定矩阵序列收敛到某个 $\mathbf{P} \geq \mathbf{0}$ 。Riccati 映射连续, 取极限便得到式 (18.19)。

令 $\mathbf{A}_K = \mathbf{A} - \mathbf{B}\mathbf{K}$ 。将 DARE 按最优增益重写为

$$\mathbf{P} - \mathbf{A}_K^\top \mathbf{P} \mathbf{A}_K = \mathbf{Q} + \mathbf{K}^\top \mathbf{R} \mathbf{K}. \quad (18.20)$$

右侧半正定。现在用可检测性排除闭环中的非衰减模式。若 $\mathbf{A}_K$ 存在特征对 $\mathbf{A}_K \mathbf{z} = \lambda \mathbf{z}$, 其中 $\mathbf{z} \neq \mathbf{0}$ 且 $|\lambda| \geq 1$, 在式 (18.20) 两侧左乘 $\mathbf{z}^*$ 、右乘 $\mathbf{z}$, 得到

$$(1 - |\lambda|^2) \mathbf{z}^* \mathbf{P} \mathbf{z} = \|\mathbf{Q}^{1/2} \mathbf{z}\|_2^2 + \|\mathbf{R}^{1/2} \mathbf{K} \mathbf{z}\|_2^2.$$

左侧非正而右侧非负, 所以两侧只能同时为零。特别地, $\mathbf{Q}^{1/2} \mathbf{z} = \mathbf{0}$ 且 $\mathbf{K} \mathbf{z} = \mathbf{0}$ 。于是

$$\mathbf{A} \mathbf{z} = (\mathbf{A}_K + \mathbf{B} \mathbf{K}) \mathbf{z} = \lambda \mathbf{z},$$

这给出了 $(\mathbf{Q}^{1/2}, \mathbf{A})$ 无法检测的危险特征向量, 与假设矛盾。因此 $\mathbf{A}_K$ 的全部特征值严格位于单位圆内, 极限解确实是稳定化解。

记 $\mathbf{S} = \mathbf{R} + \mathbf{B}^\top \mathbf{P} \mathbf{B}$ 。对任意控制序列, 把 Bellman 配方恒等式沿前 N 步求和, 得到

$$\sum_{t=0}^{N-1} (\mathbf{x}_t^\top \mathbf{Q} \mathbf{x}_t + \mathbf{u}_t^\top \mathbf{R} \mathbf{u}_t) + \mathbf{x}_N^\top \mathbf{P} \mathbf{x}_N = \mathbf{x}_0^\top \mathbf{P} \mathbf{x}_0 + \sum_{t=0}^{N-1} (\mathbf{u}_t + \mathbf{K} \mathbf{x}_t)^\top \mathbf{S} (\mathbf{u}_t + \mathbf{K} \mathbf{x}_t).$$

这里不能在令 $N \rightarrow \infty$ 时直接丢掉终端项。若某个允许控制的总成本有限, 则

$$\mathbf{Q}^{1/2} \mathbf{x}_t \rightarrow \mathbf{0}, \quad \mathbf{u}_t \rightarrow \mathbf{0};$$

第二个结论使用了 $\mathbf{R} > \mathbf{0}$ 。由 $(\mathbf{Q}^{1/2}, \mathbf{A})$ 可检测, 可选 $\mathbf{L}$ 使 $\mathbf{A} - \mathbf{L} \mathbf{Q}^{1/2}$ 稳定, 并把状态递推写成

$$\mathbf{x}_{t+1} = (\mathbf{A} - \mathbf{L} \mathbf{Q}^{1/2}) \mathbf{x}_t + \mathbf{B} \mathbf{u}_t + \mathbf{L} \mathbf{Q}^{1/2} \mathbf{x}_t.$$

右侧稳定线性系统的输入趋于零, 因此 $\mathbf{x}_t \rightarrow \mathbf{0}$, 进而 $\mathbf{x}_N^\top \mathbf{P} \mathbf{x}_N \rightarrow 0$ 。这就是可检测性在终端项论证中的具体作用。总成本无限的控制自然不可能优于稳定反馈。令 $N \rightarrow \infty$ 后, 任意有限成本控制的成本等于 $\mathbf{x}_0^\top \mathbf{P} \mathbf{x}_0$ 加上一

串

$$(\mathbf{u}_t + \mathbf{K}\mathbf{x}_t)^\top (\mathbf{R} + \mathbf{B}^\top \mathbf{P}\mathbf{B})(\mathbf{u}_t + \mathbf{K}\mathbf{x}_t)$$

的极限和。采用 $\mathbf{u}_t = -\mathbf{K}\mathbf{x}_t$ 时这些平方项为零，闭环稳定也使终端项趋零，故该反馈达到下界并最优。同一恒等式应用于两个半正定稳定化解，可知二者都表示同一最优成本，因而相等。 ■

示例中的标量 DARE 为

$$P = 1 + \frac{1.44P}{1+P}, \quad P^2 - 1.44P - 1 = 0.$$

半正定解是

$$P = \frac{1.44 + \sqrt{6.0736}}{2} \approx 1.952, \quad K = \frac{1.2P}{1+P} \approx 0.794.$$

闭环系数 $1.2 - K \approx 0.406$ ，位于单位圆内。另一个代数根为负，不表示非负无限时域成本，也不是这里的稳定化解。

可检测条件中的“输出”是 $\mathbf{Q}^{1/2}\mathbf{x}$ ，不是传感器输出 $\mathbf{C}\mathbf{x}$ 。它要求任何不被状态成本惩罚的不稳定模式都不存在。传感器的可检测性则决定估计误差能否稳定，两种条件服务于不同对象。

一个标量反例说明为何代数解和成本最优都不足以替代“稳定化”。令 $A = 1.2$ 、 $B = 1$ 、 $Q = 0$ 、 $R = 1$ 。系统可控，却因为 $Q^{1/2} = 0$ 而无法检测不稳定模式。DARE 同时有 $P = 0$ 和 $P = 0.44$ 两个半正定解：前者给出 $K = 0$ 和不稳定闭环 1.2，后者给出稳定闭环 $1.2 - 1.2P/(1+P) = 5/6$ 。然而原目标只惩罚控制，取 $\mathbf{u}_t = 0$ 便以零成本达到全局最小；稳定化解对应正控制成本，反而不是该退化目标的最优解。可检测性正是用来排除这种“不稳定状态完全免费”的情形，不能在求出某个 DARE 根以后省略。

无限时域切换到确定性系统也不是无关紧要的简化。若每一步都有非零独立加性噪声，即使闭环稳定，状态协方差通常也会收敛到非零稳态值，单步期望状态成本便不会趋于零；无折扣累计期望成本因而通常发散。此时应明确改用长期平均成本、折扣成本或有限时域目标。只有当噪声及其传播方向恰好不被成本计入等退化情形，才可能避开这一结论。

18.2.4 滤波 Riccati 与控制 Riccati 具有对偶结构

第 16 章的有限时域 Kalman 滤波在每一步先传播协方差，再用新观测修正。若采用预测协方差 Π_t ，状态噪声协方差为 $\Sigma_w \geq 0$ ，观测噪声协方差为 $\Sigma_v > 0$ ，稳态预测方程可写成

$$\Pi = \mathbf{A}\Pi\mathbf{A}^\top + \Sigma_w - \mathbf{A}\Pi\mathbf{C}^\top (\mathbf{C}\Pi\mathbf{C}^\top + \Sigma_v)^{-1} \mathbf{C}\Pi\mathbf{A}^\top. \quad (18.21)$$

这里 Π 是观测 y_t 到来之前的预测误差协方差。令

$$\hat{\mathbf{x}}_{t|t-1} = \mathbb{E}[\mathbf{x}_t | \mathbf{y}_{t-1}],$$

其中 $\mathbf{y}_{t-1}$ 包含截至 $t-1$ 的观测和已执行控制，并在稳态记

$$\Pi = \mathbb{E}[(\mathbf{x}_t - \hat{\mathbf{x}}_{t|t-1})(\mathbf{x}_t - \hat{\mathbf{x}}_{t|t-1})^\top].$$

采用观测模型 $\mathbf{y}_t = \mathbf{C}\mathbf{x}_t + \mathbf{v}_t$ 时，与式 (18.21) 口径一致的合并观测更新与一步预测为

$$\hat{\mathbf{x}}_{t+1|t} = \mathbf{A}\hat{\mathbf{x}}_{t|t-1} + \mathbf{B}\mathbf{u}_t + \mathbf{L}(\mathbf{y}_t - \mathbf{C}\hat{\mathbf{x}}_{t|t-1}),$$

其中

$$\mathbf{L} = \mathbf{A}\Pi\mathbf{C}^\top(\mathbf{C}\Pi\mathbf{C}^\top + \Sigma_v)^{-1}.$$

因此齐次预测误差矩阵是 $\mathbf{A} - \mathbf{LC}$ 。若把 $\Pi\mathbf{C}^\top(\mathbf{C}\Pi\mathbf{C}^\top + \Sigma_v)^{-1}$ 称为观测更新增益，则从更新后估计传播到下一时刻时还要左乘 $\mathbf{A}$ ；两种增益不能在同一个协方差口径下混用。

将控制 DARE 中的

$$\mathbf{A} \leftrightarrow \mathbf{A}^\top, \quad \mathbf{B} \leftrightarrow \mathbf{C}^\top, \quad \mathbf{Q} \leftrightarrow \Sigma_w, \quad \mathbf{R} \leftrightarrow \Sigma_v,$$

便得到这一形式。控制增益用输入压低状态成本，滤波增益用观测压低估计误差协方差；公式对偶不表示两者的随机变量含义相同。

一个常用的充分条件是 $(\mathbf{C}, \mathbf{A})$ 可检测、 $(\mathbf{A}, \Sigma_w^{1/2})$ 可稳定且 $\Sigma_v > \mathbf{0}$ 。在这些条件及标准独立噪声假设下，协方差递推收敛到唯一稳定化半正定解，稳态滤波增益使估计误差动态稳定。可检测性保证危险状态模式能从观测纠正；过程噪声对偶条件排除 Riccati 方程在不稳定方向上的退化。有限时域滤波本身不要求协方差已经收敛，稳态公式也不能在系统时变、噪声统计变化或模型严重错设时直接替代逐时递推。

滤波结果怎样进入控制，还需要一条信息接口。在线性动态、二次成本、高斯初值与独立加性高斯噪声的标准有限时域设定中，令

$$\hat{\mathbf{x}}_t = \mathbb{E}[\mathbf{x}_t | \mathbf{y}_t], \quad \mathbf{e}_t = \mathbf{x}_t - \hat{\mathbf{x}}_t,$$

其中 $\mathbf{y}_t$ 包含截至 t 的观测和已执行控制。条件期望的投影性质给出

$$\mathbb{E}[\mathbf{e}_t | \mathbf{y}_t] = \mathbf{0}, \quad \mathbb{E}[\hat{\mathbf{x}}_t^\top \mathbf{Q} \mathbf{e}_t] = 0.$$

因此条件状态成本分解为估计均值的二次成本与误差协方差项；在该设定下，Kalman 误差协方差递推又不依赖所选控制值。Bellman 递推中与当前

动作有关的部分遂与完全状态 LQR 相同, 只需把真实状态换成条件均值:

$$\mathbf{u}_t^* = -\mathbf{K}_t \hat{\mathbf{x}}_t.$$

这就是线性二次高斯控制中的**分离原则**: Kalman 滤波器按估计误差设计, LQR 增益按行动成本设计, 再通过估计均值连接。它比前文确定性观测器的谱分离多给出期望成本最优性, 但依赖噪声、信息和二次目标的特殊结构; 受控观测噪声、风险敏感目标、输入或状态约束都可能使估计价值依赖未来控制, 从而破坏这一分离。

18.3 安全不变集与控制屏障函数

18.3.1 稳定、最优与安全是三个不同要求

LQR 惩罚偏离和控制强度, 所得反馈对给定二次目标最优。但有限代价或渐近稳定都不保证状态从未越过危险区域。一个制动系统最终回到零速度, 仍可能在停止前越过边界; 一个平均成本很小的随机系统, 也可能存在少量不可接受轨迹。安全控制需要逐轨迹描述允许状态, 并证明闭环向量场不会把状态推出该集合。

离散系统可以先用一步条件看清这一要求。设闭环映射为 $\mathbf{x}_{t+1} = F_k(\mathbf{x}_t)$, 安全集合为 S 。若

$$F_k(S) \subseteq S, \quad (18.22)$$

则从 $\mathbf{x}_0 \in S$ 出发, 归纳可得 $\mathbf{x}_1 \in S$, 继而 $\mathbf{x}_2 \in S$, 并对每个 $t \geq 0$ 都有 $\mathbf{x}_t \in S$ 。反过来, 若要求 S 中的每个初态都正向不变, 取任意 $\mathbf{x} \in S$ 考察第一步, 就必须有 $F_k(\mathbf{x}) \in S$ 。因此式 (18.22) 对确定性离散闭环既充分又必要。

例如, 对 $\mathbf{x}_{t+1} = \mathbf{x}_t + \mathbf{u}_t$ 取安全集合 $S = [0, \infty)$ 。反馈 $u_t = -1.5x_t$ 产生 $x_{t+1} = -0.5x_t$, 状态幅值会趋于零, 却从任意 $x_0 > 0$ 在第一步就越过安全边界; 反馈 $u_t = -0.5x_t$ 则产生 $x_{t+1} = 0.5x_t$, 既渐近稳定又保持非负。原系统能够到达负半轴只说明它可达, 不能说明所选闭环应该到达那里。这个例子把可达、稳定与安全分成了三个不同判断。

连续时间不能只检查采样时刻的一步映射, 因为轨迹可能在两个采样点之间越界。考虑控制仿射系统

$$\dot{\mathbf{x}} = \mathbf{f}(\mathbf{x}) + \mathbf{G}(\mathbf{x})\mathbf{u}, \quad \mathbf{u} \in U, \quad (18.23)$$

其中 $\mathbf{x} \in \mathbb{R}^n$, $\mathbf{u} \in \mathbb{R}^m$, $\mathbf{G}(\mathbf{x}) \in \mathbb{R}^{n \times m}$ 。假设 $\mathbf{f}$ 和 $\mathbf{G}$ 局部 Lipschitz, 所选反馈使闭环解存在且唯一。用连续可微函数 $h: \mathbb{R}^n \rightarrow \mathbb{R}$ 定义安全集合

$$S = \{\mathbf{x} : h(\mathbf{x}) \geq 0\}. \quad (18.24)$$

定义 18.9 正向不变集 若从任意 $\mathbf{x}_0 \in S$ 出发, 闭环解在其存在的全部未来时刻都满足 $\mathbf{x}(t) \in S$, 则称 S 对该闭环系统正向不变。

当边界 $\partial S = \{\mathbf{x} : h(\mathbf{x}) = 0\}$ 光滑且 $\nabla h(\mathbf{x}) \neq \mathbf{0}$ 时, 集合内侧对应 h 增大的方向。Nagumo 切锥条件在这里化为: 边界上的闭环速度必须指向集合内部或与边界相切,

$$\dot{h}(\mathbf{x}) = \nabla h(\mathbf{x})^\top (\mathbf{f}(\mathbf{x}) + \mathbf{G}(\mathbf{x})\mathbf{u}) \geq 0 \quad \text{当 } h(\mathbf{x}) = 0. \quad (18.25)$$

只在边界检查这个条件适合理论判定, 但控制器还需要在接近边界时提前限制动作。

18.3.2 控制屏障函数把集合保持化为动作约束

记 Lie 导数

$$L_f h(\mathbf{x}) = \nabla h(\mathbf{x})^\top \mathbf{f}(\mathbf{x}), \quad L_G h(\mathbf{x}) = \nabla h(\mathbf{x})^\top \mathbf{G}(\mathbf{x}).$$

本章把连续、严格递增、局部 Lipschitz 且满足 $\alpha(0) = 0$ 的函数 $\alpha : \mathbb{R} \rightarrow \mathbb{R}$ 称为扩展类 $\mathcal{K}$ 函数。局部 Lipschitz 条件保证下文标量比较系统的解局部唯一。常用选择是 $\alpha(r) = \gamma r$, 其中 $\gamma > 0$ 。

定义 18.10 零化控制屏障函数 若在某个包含 S 的开区域 D 内, 对每个 $\mathbf{x}$ 都有

$$\sup_{\mathbf{u} \in U} \{L_f h(\mathbf{x}) + L_G h(\mathbf{x})\mathbf{u}\} \geq -\alpha(h(\mathbf{x})), \quad (18.26)$$

并且上述上确界能够由某个 $\mathbf{u} \in U$ 取到, 则称 h 为区域 D 上的控制屏障函数 (control barrier function, CBF)。

这一条件及其基于二次规划的安全控制构造可参见控制屏障函数的系统论述²。当 U 紧且花括号内的函数关于动作连续时, 上确界能够取到; 若这些条件不成立, 只有上确界的数值不小于阈值, 仍可能找不到真正满足约束的动作。定义保证每个状态至少存在一个安全动作, 但实际反馈还必须从可行动作集合

$$K_{\text{cbf}}(\mathbf{x}) = \{\mathbf{u} \in U : L_f h(\mathbf{x}) + L_G h(\mathbf{x})\mathbf{u} \geq -\alpha(h(\mathbf{x}))\} \quad (18.27)$$

中作出足够规则的选择。

² A. D. Ames, X. Xu, J. W. Grizzle, P. Tabuada, *Control Barrier Function Based Quadratic Programs for Safety Critical Systems* In IEEE Transactions on Automatic Control, 2017, vol. 62, no. 8, pp. 3861–3876

定理 18.11 CBF 条件保证正向不变 设式 (18.23) 与式 (18.24) 满足上述正则条件。若反馈 $\mathbf{u} = \kappa(\mathbf{x})$ 局部 Lipschitz, 并对开区域 D 内每个状态满足 $\kappa(\mathbf{x}) \in K_{\text{cbf}}(\mathbf{x})$, 则 S 在相应闭环解存在的时间区间内正向不变。

证明. 沿任意闭环解令 $r(t) = h(\mathbf{x}(t))$ 。链式法则与 CBF 约束给出

$$\dot{r}(t) \geq -\alpha(r(t)).$$

考虑标量比较系统

$$\dot{z}(t) = -\alpha(z(t)), \quad z(0) = r(0) \geq 0.$$

由于 α 局部 Lipschitz 且 $\alpha(0) = 0$, 标量比较系统在其最大存在区间内解唯一, $z = 0$ 是平衡解; 从非负初值出发的 $z(t)$ 因而不能穿过零点。在闭环轨迹位于 D 且解存在的任意时间区间内, 标量比较原理给出 $r(t) \geq z(t) \geq 0$ 。又因为 D 是包含 S 的开区域, 轨迹若要离开 S , 必先在 D 内穿过 $h = 0$ 进入 $h < 0$, 这与上述比较结论矛盾。因此 $\mathbf{x}(t) \in S$ 在闭环解存在的全部时间内成立。

对最常用的 $\alpha(r) = \gamma r$, 结论可以直接验证:

$$\frac{d}{dt} (e^{\gamma t} r(t)) = e^{\gamma t} (\dot{r}(t) + \gamma r(t)) \geq 0.$$

故 $r(t) \geq e^{-\gamma t} r(0) \geq 0$ 。边界上 $r = 0$ 时, 该约束退化为 $\dot{r} \geq 0$, 与式 (18.25) 一致。 ■

该定理给出的是闭环轨迹性质, 不只是某一步动作看起来朝向内部。证明依赖约束始终可行、反馈与动态具有足够正则性, 以及控制信号按连续时间模型实际施加。缺少其中任一项, 导数不等式都未必能沿真实轨迹成立。

18.3.3 二次规划可以最小修改已有控制器

设 $\mathbf{u}_{\text{nom}}(\mathbf{x})$ 是为性能设计的已有控制器, 例如 LQR 反馈。可以在每个状态求解

$$\begin{aligned} \mathbf{u}^*(\mathbf{x}) \in \arg \min_{\mathbf{u} \in U} \quad & \frac{1}{2} (\mathbf{u} - \mathbf{u}_{\text{nom}})^\top \mathbf{H} (\mathbf{u} - \mathbf{u}_{\text{nom}}) \\ \text{s.t.} \quad & L_f h(\mathbf{x}) + L_G h(\mathbf{x}) \mathbf{u} \geq -\alpha(h(\mathbf{x})), \end{aligned} \quad (18.28)$$

其中 $\mathbf{H} > \mathbf{0}$ 规定修改不同控制分量的代价。对控制仿射系统, CBF 条件关于 $\mathbf{u}$ 是线性不等式; 若 U 是非空闭凸集, 这就是具有闭凸可行域的凸

二次规划。目标只表示“在该度量下尽量接近名义动作”，不表示修改后的控制仍保持原 LQR 成本最优。

示例 18.12 一维积分器上的安全投影 考虑 $\dot{x} = u$ 与安全集合 $S = [0, \infty)$, 取 $h(x) = x$ 和 $\alpha(h) = \gamma h$, 其中 $\gamma > 0$ 。因为 $L_f h = 0$ 、 $L_g h = 1$, CBF 条件正好是

$$u \geq -\gamma x.$$

若 $U = \mathbb{R}$ 、 $H = 1$, 式 (18.28) 的解是把标量名义动作投影到半直线 $[-\gamma x, \infty)$:

$$u^*(x) = \max\{u_{\text{nom}}(x), -\gamma x\}. \quad (18.29)$$

例如 $x = 0.2$ 、 $\gamma = 1$ 且 $u_{\text{nom}} = -1$ 时, 安全修正为 $u^* = -0.2$, 并使 $\dot{h} = -h$; 状态按 $x(t) = 0.2e^{-t}$ 接近边界但不穿过。若执行器还要求 $u \leq -0.5$, 则此状态下输入约束与 CBF 条件不相容, QP 不可行。可行性取决于安全要求、当前状态与执行器能力的联合关系, 不能由 h 的形式单独保证。

在 U 非空闭凸的上述条件下, 若 QP 可行, 则可行域非空且闭; 正定二次目标具有强制性, 因而最优解存在, 严格凸性进一步保证最优动作唯一。若不要求可行域闭, 严格凸性只能说明已有最优解至多一个, 不能保证下确界能够取到。即使最优动作存在且唯一, 也不自动意味着映射 $\mathbf{x} \mapsto \mathbf{u}^*(\mathbf{x})$ 局部 Lipschitz。活跃约束切换、约束梯度退化或可行域突变都可能破坏反馈正则性; 要调用定理 18.11, 还需用约束资格条件和参数化优化结果核对所选解的连续性或局部 Lipschitz 性质。

示例 18.13 圆形障碍外的安全修正 考虑平面单积分器 $\dot{\mathbf{p}} = \mathbf{u}$, 要求位置留在圆形障碍外。令障碍中心为 $\mathbf{c}$ 、半径为 $r > 0$, 取

$$h(\mathbf{p}) = \|\mathbf{p} - \mathbf{c}\|_2^2 - r^2.$$

安全集合是 $h \geq 0$ 。选择 $\alpha(h) = \gamma h$ 后, CBF 约束为

$$2(\mathbf{p} - \mathbf{c})^\top \mathbf{u} \geq -\gamma(\|\mathbf{p} - \mathbf{c}\|_2^2 - r^2). \quad (18.30)$$

在边界点 $\mathbf{p} - \mathbf{c} = (r, 0)^\top$ 处, 若名义控制 $\mathbf{u}_{\text{nom}} = (-v, 0)^\top$ 且 $v > 0$, 它会直接指向障碍内部, 因为左侧为 $-2rv < 0$ 。取 $\mathbf{H} = \mathbf{I}$ 且没有其他输入约束时, 二次规划把名义动作正交投影到半空间 $2(\mathbf{p} - \mathbf{c})^\top \mathbf{u} \geq 0$; 在该边界点, 修正结果为 $\mathbf{u}^* = \mathbf{0}$ 。若名义动作还含切向分量, 投影会保留切向分量, 只移除指向障碍内部的法向分量。

多个安全条件 $h_i(\mathbf{x}) \geq 0$ 可以产生多条线性约束, 但每条单独可行不代

表它们与执行器限制联合可行。两个障碍可能把系统夹在没有允许动作的位置；速度、转角或推力上限也可能阻止及时避让。加入松弛变量能够让优化器总有数值解，却同时允许违反安全约束。若这样做，松弛后的 QP 不再提供原来的硬不变性保证，必须明确新的故障处理或恢复区域。

18.3.4 扰动、采样和相对阶会改变保证条件

若真实动态含有有界加性扰动

$$\dot{\mathbf{x}} = \mathbf{f}(\mathbf{x}) + \mathbf{G}(\mathbf{x})\mathbf{u} + \mathbf{d}, \quad \|\mathbf{d}\|_2 \leq \delta,$$

则最坏方向可使 $\dot{h}$ 减少 $\|\nabla h(\mathbf{x})\|_2 \delta$ 。一个鲁棒充分条件是

$$L_f h + L_G h \mathbf{u} \geq -\alpha(h) + \|\nabla h\|_2 \delta. \quad (18.31)$$

模型误差也可在已有有效上界时并入类似裕量。没有经过验证的误差界时，任意加一个“安全系数”只能形成经验缓冲，不能推出鲁棒不变性。

数字控制器通常每隔 Δ 秒求一次动作，并在两次更新之间保持不变。采样时刻满足 CBF 约束，不自动保证区间内部也满足，因为状态、Lie 导数和最危险动作可能在区间中变化。可行做法包括用 Lipschitz 界为采样间变化预留裕量、直接建立离散时间屏障条件

$$h(\mathbf{x}_{t+1}) - h(\mathbf{x}_t) \geq -\alpha_d(h(\mathbf{x}_t)),$$

其中离散比较函数应对每个 $r \geq 0$ 满足 $0 \leq \alpha_d(r) \leq r$ 。这样，只要 $h(\mathbf{x}_t) \geq 0$ ，就有

$$h(\mathbf{x}_{t+1}) \geq h(\mathbf{x}_t) - \alpha_d(h(\mathbf{x}_t)) \geq 0,$$

从而可以逐步归纳安全性。常用线性选择是 $\alpha_d(r) = \gamma r$ ，其中 $0 < \gamma \leq 1$ 。另一种做法是在预测时域内验证整段轨迹。连续时间证明不能省略这一实现差异。

还有一类问题来自**相对阶**。若 $L_G h(\mathbf{x}) = \mathbf{0}$ ，控制不出现在 h 的一阶导数中，式 (18.27) 便无法限制动作。例如双积分器

$$\dot{p} = v, \quad \dot{v} = u$$

若用 $h(p) = p - p_{\min}$ 保护位置下界，则 $\dot{h} = v$ 与 u 无关，控制要到 $\ddot{h} = u$ 才出现。此时需使用高阶 CBF，递归约束 $h, \dot{h}$ 及更高导数，或把速度制动距离纳入安全函数。把一阶公式机械套到 $L_G h = 0$ 的情形，只会得到与控制无关的条件。

CBF 还假设控制器知道用于计算 h 的状态。若只有带误差的状态估计，应对估计误差建立集合界或概率模型，再收紧安全集或构造输出反馈屏

障。把估计值直接当作真实状态代入，只能证明估计轨迹满足约束，不能自动证明真实轨迹安全。

18.4 动态优化与连续控制

18.4.1 短时间 Bellman 原理产生局部方程

有限时域 LQR 利用离散 Bellman 递推。连续时间中没有固定的一步，但可以把任意短区间 $[t, t + \Delta]$ 视为第一步。考虑确定性受控系统

$$\dot{\mathbf{x}}(s) = \mathbf{f}(\mathbf{x}(s), \mathbf{u}(s), s), \quad \mathbf{x}(t) = \mathbf{x}, \quad (18.32)$$

以及成本

$$J_{t,\mathbf{x}}(\mathbf{u}) = \phi(\mathbf{x}(T)) + \int_t^T \ell(\mathbf{x}(s), \mathbf{u}(s), s) ds. \quad (18.33)$$

价值函数为 $V(\mathbf{x}, t) = \inf_{\mathbf{u}} J_{t,\mathbf{x}}(\mathbf{u})$ 。控制 $\mathbf{u}(s)$ 只能依据时刻 s 已经可用的信息；确定性完全状态反馈下，这通常表示它由当前或过去状态决定，而不能预知未来扰动。

动态规划原理把最优成本拆成短区间成本与剩余价值：

$$V(\mathbf{x}, t) = \inf_{\mathbf{u}|_{[t, t+\Delta]}} \left\{ \int_t^{t+\Delta} \ell(\mathbf{x}(s), \mathbf{u}(s), s) ds + V(\mathbf{x}(t + \Delta), t + \Delta) \right\}. \quad (18.34)$$

下面给出经典形式推导。除假设 V 连续可微外，还假设动态规划原理成立， $\mathbf{f}$ 与 ℓ 具有使短时轨迹偏移为 $O(\Delta)$ 的连续性，并且短区间下确界可由可测的 $\eta\Delta$ -最优控制逼近，相关 Taylor 余项对这些控制局部一致。先在短区间内取任意常值动作 $\mathbf{u}$ 。Taylor 展开给出

$$\begin{aligned} V(\mathbf{x}(t + \Delta), t + \Delta) &= V(\mathbf{x}, t) + \Delta \partial_t V(\mathbf{x}, t) \\ &\quad + \Delta \nabla_{\mathbf{x}} V(\mathbf{x}, t)^\top \mathbf{f}(\mathbf{x}, \mathbf{u}, t) + o(\Delta), \end{aligned}$$

而阶段积分为 $\Delta \ell(\mathbf{x}, \mathbf{u}, t) + o(\Delta)$ 。由于式 (18.34) 对全部短时控制取下确界，代入这个常值动作只能先得到

$$-\partial_t V(\mathbf{x}, t) \leq \ell(\mathbf{x}, \mathbf{u}, t) + \nabla_{\mathbf{x}} V(\mathbf{x}, t)^\top \mathbf{f}(\mathbf{x}, \mathbf{u}, t).$$

该式对每个 $\mathbf{u} \in U$ 成立，故左侧不大于右侧对动作的下确界。

还需证明反向不等式。对任意 $\eta > 0$ ，在长度为 Δ 的短区间上选择一个目标值距离下确界不超过 $\eta\Delta$ 的允许控制。沿这条短时轨迹展开阶段成本和剩余价值，并利用每个时刻的 Hamilton 量都不小于其对动作的下确界，

可得

$$\partial_t V(\mathbf{x}, t) + \inf_{\mathbf{u} \in U} \{ \ell(\mathbf{x}, \mathbf{u}, t) + \nabla_{\mathbf{x}} V(\mathbf{x}, t)^\top \mathbf{f}(\mathbf{x}, \mathbf{u}, t) \} \leq \eta + o(1).$$

依次令 $\Delta \downarrow 0$ 和 $\eta \downarrow 0$ 便得到反向不等式。两边合并, 得到 **Hamilton–Jacobi–Bellman 方程**:

$$-\partial_t V(\mathbf{x}, t) = \inf_{\mathbf{u} \in U} \{ \ell(\mathbf{x}, \mathbf{u}, t) + \nabla_{\mathbf{x}} V(\mathbf{x}, t)^\top \mathbf{f}(\mathbf{x}, \mathbf{u}, t) \}, \quad V(\mathbf{x}, T) = \phi(\mathbf{x}). \quad (18.35)$$

花括号内的量常称为控制问题的 Hamilton 量, 它把瞬时成本与价值沿当前速度的变化率相加, 再对动作作局部优化。它不是第 16 章 Hamilton 系统中沿轨迹守恒的能量函数; 二者名称相近, 所描述的对象和方程不同。这里采用成本最小化约定, 所以写 $\inf$ 和 $-\partial_t V$; 若改为奖励最大化, 符号必须成套改变³。

定理 18.14 确定性 HJB 验证定理 设 $V \in C^1$ 满足式 (18.35) 及终端条件, 并假设任意允许控制都产生存在到 T 的轨迹。若存在可实现反馈 $\mathbf{u}^* = \kappa(\mathbf{x}, t)$ 逐点达到 HJB 右侧的下确界, 且相应闭环轨迹存在, 则 V 等于最优价值, κ 是最优反馈。

³ M. Bardi, I. Capuzzo-Dolcetta, *Optimal Control and Viscosity Solutions of Hamilton–Jacobi–Bellman Equations*, Birkhäuser, 1997

证明. 任取一个允许控制 $\mathbf{u}(s)$ 及其轨迹。HJB 中的下确界不大于代入该动作后的值, 所以

$$\partial_s V(\mathbf{x}(s), s) + \nabla_{\mathbf{x}} V(\mathbf{x}(s), s)^\top \mathbf{f}(\mathbf{x}(s), \mathbf{u}(s), s) + \ell(\mathbf{x}(s), \mathbf{u}(s), s) \geq 0.$$

链式法则把前两项合成 $dV(\mathbf{x}(s), s)/ds$ 。从 t 积分到 T , 并用 $V(\mathbf{x}(T), T) = \phi(\mathbf{x}(T))$, 得到

$$J_{t, \mathbf{x}}(\mathbf{u}) \geq V(\mathbf{x}, t).$$

因此 V 是所有允许控制成本的下界。

采用 $\mathbf{u}^* = \kappa(\mathbf{x}, s)$ 时, 反馈在每一点达到 HJB 下确界, 上述不等式处处取等号。沿闭环轨迹积分便有 $J_{t, \mathbf{x}}(\mathbf{u}^*) = V(\mathbf{x}, t)$ 。所以该反馈达到共同下界, V 就是最优价值。■

HJB 方程是最优性的局部必要关系; 验证定理则说明一个足够光滑的候选解如何成为全局证书。仅把偏微分方程在若干采样点上的残差降得很小, 还不能自动获得验证结论, 因为还需终端或边界条件、可实现的极小动作、轨迹存在性以及整个相关区域上的方程关系。

18.4.2 随机动态多出二阶扩散项

若状态服从 Itô 随机微分方程

$$dX_s = f(X_s, u_s, s) ds + \Sigma(X_s, u_s, s) dW_s, \quad (18.36)$$

控制 u_s 必须对当前滤过适应, 不能使用未来布朗增量。价值改为期望成本的下确界。对 $V \in C^{2,1}$ 使用第 16 章的 Itô 公式, 短时间条件期望中一阶随机积分均值为零, 二次变差留下

$$\frac{1}{2} \text{tr}(\Sigma \Sigma^\top \nabla_x^2 V).$$

因此随机 HJB 为

$$\begin{aligned} -\partial_t V(x, t) = \inf_{u \in U} \bigg\{ & \ell(x, u, t) + \nabla_x V(x, t)^\top f(x, u, t) \\ & + \frac{1}{2} \text{tr}[\Sigma(x, u, t) \Sigma(x, u, t)^\top \nabla_x^2 V(x, t)] \bigg\}, \end{aligned} \quad (18.37)$$

终端条件仍为 $V(x, T) = \phi(x)$ 。

定理 18.15 随机 HJB 验证 设 V 对时间一次、对状态二次连续可微, 满足式 (18.37) 及终端条件。假设每个允许的适应控制都使式 (18.36) 存在到 T , 成本和下述 Itô 各项可积, 并且随机积分是真鞅。若存在可容许的反馈 $u^* = \kappa(x, t)$ 逐点达到 HJB 中的下确界, 则 V 等于最优期望成本, κ 是最优反馈。

证明. 记动作 u 下的受控生成元为

$$\mathcal{L}^u V = \nabla_x V^\top f + \frac{1}{2} \text{tr}(\Sigma \Sigma^\top \nabla_x^2 V).$$

HJB 说明, 对任意允许动作都有

$$\partial_s V + \mathcal{L}^{u_s} V + \ell(X_s, u_s, s) \geq 0.$$

沿受控轨迹对 $V(X_s, s)$ 使用 Itô 公式, 从 t 积分到 T 并取条件期望。随机积分因真鞅条件期望为零, 故

$$\mathbb{E} \left[\phi(X_T) + \int_t^T \ell(X_s, u_s, s) ds \middle| X_t = x \right] \geq V(x, t).$$

所以 V 是所有允许控制期望成本的下界。对反馈 κ , HJB 下确界逐点达到, 上述生成元不等式取等号; 重复同一计算便得到其期望成本恰为 $V(x, t)$, 从而完成验证。 ■

若随机积分只是局部鞅，直接断言其期望为零可能失败；通常需要增长界、停时局部化与一致可积性等条件把局部结论提升为上述等式。随机 HJB 的局部形式本身不能替代这些可积性检查。

若扩散矩阵与动作无关，且价值是二次函数，二阶项可能只增加与状态无关的常数，这与离散 LQR 中式 (18.18) 的现象一致。若 Σ 依赖动作或状态，二阶项会参与动作最小化或改变价值的状态形状，反馈一般也会改变。

18.4.3 连续时间 LQR 给出微分 Riccati 方程

用 HJB 重新考察线性二次问题。令

$$\dot{\mathbf{x}} = \mathbf{A}\mathbf{x} + \mathbf{B}\mathbf{u},$$

阶段成本和终端成本分别为

$$\ell(\mathbf{x}, \mathbf{u}) = \mathbf{x}^\top \mathbf{Q}\mathbf{x} + \mathbf{u}^\top \mathbf{R}\mathbf{u}, \quad \phi(\mathbf{x}) = \mathbf{x}^\top \mathbf{Q}_T \mathbf{x},$$

其中 $\mathbf{Q}, \mathbf{Q}_T \geq \mathbf{0}$ 、 $\mathbf{R} > \mathbf{0}$ 。设

$$V(\mathbf{x}, t) = \mathbf{x}^\top \mathbf{P}(t) \mathbf{x}, \quad \mathbf{P}(T) = \mathbf{Q}_T,$$

并取 $\mathbf{P}(t)$ 对称。于是

$$\partial_t V = \mathbf{x}^\top \dot{\mathbf{P}}(t) \mathbf{x}, \quad \nabla_{\mathbf{x}} V = 2\mathbf{P}(t) \mathbf{x}.$$

代入确定性 HJB，动作相关项为

$$\mathbf{u}^\top \mathbf{R}\mathbf{u} + 2\mathbf{x}^\top \mathbf{P}\mathbf{B}\mathbf{u}.$$

同样配方：

$$\begin{aligned} & \mathbf{u}^\top \mathbf{R}\mathbf{u} + 2\mathbf{x}^\top \mathbf{P}\mathbf{B}\mathbf{u} \\ &= \left(\mathbf{u} + \mathbf{R}^{-1} \mathbf{B}^\top \mathbf{P}\mathbf{x} \right)^\top \mathbf{R} \left(\mathbf{u} + \mathbf{R}^{-1} \mathbf{B}^\top \mathbf{P}\mathbf{x} \right) - \mathbf{x}^\top \mathbf{P}\mathbf{B}\mathbf{R}^{-1} \mathbf{B}^\top \mathbf{P}\mathbf{x}. \end{aligned}$$

所以最优反馈为

$$\mathbf{u}^*(t) = -\mathbf{R}^{-1} \mathbf{B}^\top \mathbf{P}(t) \mathbf{x}(t), \quad (18.38)$$

而对任意 $\mathbf{x}$ 比较二次型系数，得到

$$-\dot{\mathbf{P}} = \mathbf{Q} + \mathbf{A}^\top \mathbf{P} + \mathbf{P}\mathbf{A} - \mathbf{P}\mathbf{B}\mathbf{R}^{-1} \mathbf{B}^\top \mathbf{P}, \quad \mathbf{P}(T) = \mathbf{Q}_T. \quad (18.39)$$

这就是连续时间微分 Riccati 方程。它从终端条件向较早时刻反向积分；式中的负号反映价值边界给在终点，而不是数值积分器可以任意忽略的记号。

无限时域稳态令 $\dot{P} = 0$ ，得到连续代数 Riccati 方程

$$0 = Q + A^T P + P A - P B R^{-1} B^T P. \quad (18.40)$$

此时稳定的含义改为闭环矩阵 $A - B R^{-1} B^T P$ 的全部特征值实部为负。在连续时间版本的可稳定、可检测条件下，选取半正定稳定化解可得到无限时域最优反馈。离散 DARE 和连续 CARE 外形相近，却分别对应单位圆和左半平面的稳定区域，不能混用。

18.4.4 非光滑价值需要广义解，部分观测需要改变状态

经典 HJB 推导假设价值足够光滑，但最优控制常产生切换面、状态约束或不可微终端成本。此时价值可能连续却没有处处可用的梯度或 Hessian 矩阵。**黏性解** (viscosity solution) 用光滑测试函数从上方或下方接触价值，在接触点分别施加 HJB 不等式，从而不要求价值本身处处可微。在比较原理成立的函数类中，黏性子解和上解的次序可以给出唯一性。这里保留的关键认识是：非光滑并不意味着可以任意忽略 HJB，而是要改变“满足方程”的定义；具体比较原理仍依赖连续性、增长条件、控制集和 Hamilton 量结构。

一维最短到达问题说明为什么必须先区分延续域与目标边界。令 $\dot{x} = u$ 、 $|u| \leq 1$ ，每经过一单位时间支付成本 1，到达目标集合 $\{0\}$ 时终止。最短到达时间是

$$V(x) = |x|.$$

在 $x \neq 0$ 处，稳态 HJB 为

$$0 = 1 + \inf_{|u| \leq 1} V'(x)u = 1 - |V'(x)|,$$

最优控制分别取 $u = -1$ 和 $u = 1$ ，把左右两侧的状态推向原点。价值在 $x = 0$ 处没有经典导数，但 $x = 0$ 是退出目标边界，不属于延续域 $\mathbb{R} \setminus \{0\}$ ；HJB 在两个延续分支上都由经典导数满足，目标点只需施加 $V(0) = 0$ 的边界条件。因此，这个例子说明全局价值可以在目标边界非光滑，却不能单独证明延续域内部必须使用黏性解。只有当切换面、状态约束或非光滑终端数据使折点落在方程作用域内时，才需要用上方或下方的光滑测试函数解释该点的 HJB 不等式；相应唯一性仍依赖当前边界条件、函数增长类和 Hamilton 量的比较原理。

状态约束也需要边界条件。若边界不可穿越，价值只在可行控制存在的区域定义，HJB 必须与可行方向或状态约束边界条件共同解释。若允许碰到边界后终止，则应给出退出成本。仅在区域内部求出一个光滑解，不能决定边界上的控制含义。

当真实状态不可见时，把 x 直接作为 HJB 状态也不可实现。一般做法

是把给定观测历史的条件状态分布作为**信念状态**；它包含当前决策所需的信息，但通常是无限维对象。线性高斯二次问题具有特殊的分离结构，可以用 Kalman 估计配合 LQR 反馈；一般部分观测、风险敏感或受约束问题则不能从分离原理直接推出最优性。

HJB、LQR 和 CBF 之间也有清楚边界。HJB 寻找指定成本下的最优反馈，CBF 把安全性写成每个状态的动作可行约束。可以在 HJB 中加入状态约束，也可以用 CBF-QP 修正性能控制器，但前者需要求解受约束动态优化，后者通常牺牲原性能最优性。稳定价值函数、最优价值函数和屏障函数都沿轨迹考察标量变化，却分别证明收敛、最优和不变性，不能只因公式都含导数就互相替代。

18.5 本章小结

控制把给定输入下的状态演化改成闭环选择问题。在线性系统中，可控性要求输入能够生成全部状态方向，可稳定性只要求输入能够改变不稳定模式；可观测性要求输出区分全部初态，可检测性只要求不可见模式自行稳定。秩判据给出有限时域的整体检查，PBH 判据直接定位危险特征模式。可稳定与可检测共同支持观测器和状态反馈的分离设计，但这个结论依赖线性结构及相应信息条件。

有限时域 LQR 把线性动态、二次成本和 Bellman 递推闭合在二次价值函数族中。逐步配方给出线性反馈增益与 Riccati 反向递推；零均值独立加性噪声只增加价值常数项。本章的无折扣无限时域 LQR 改用确定性系统：它不能接受任意代数 Riccati 根，而要在可稳定、可检测及代价正定条件下选择半正定稳定化解。滤波 Riccati 与控制 Riccati 具有矩阵对偶结构；在标准线性高斯条件下，条件状态均值可以接入 LQR 反馈而保持期望成本最优，但信息、噪声或约束改变后必须重新验证分离。

成本最优不等于安全。正向不变性要求每条闭环轨迹持续留在允许集合内；CBF 将边界方向条件扩展为集合附近的动作不等式，并可通过二次规划最小修改名义控制器。该保证以动作约束可行、反馈正则、状态信息可靠和连续模型与实际执行一致为前提。扰动、模型误差、采样保持、输入上限和高相对阶都会改变需要验证的条件。

连续时间 Bellman 原理在短时间极限下产生 HJB 方程；随机动态借助 Itô 公式多出扩散的二阶项。验证定理把 HJB 解、达到极小值的反馈和全时域最优性连接起来，连续时间 LQR 则把这一关系化为微分与代数 Riccati 方程。价值在 HJB 作用域内非光滑时需要黏性解等广义概念，目标边界上的非光滑则要与边界条件一同解释；部分观测需要信念状态或具有专门分离结构的估计器。由此可以区分本章的三类保证：稳定性控制长期衰减，最优性比较累计成本，安全性保持允许集合；完整的受控系统往往需要同时核对三者。

第 19 章将放开“环境规律与其他参与者策略固定”这一前提，研究多方同时调整行动时的响应、均衡与学习保证。

博弈论与多方决策

第 17 章把环境规律看作给定条件，第 18 章则让单个控制器通过反馈改变状态。多方决策进一步改变了“其他行动规则固定”这一前提。若另一方也会观察、推断和调整，当前行动的后果就取决于双方策略，而不能只对一个固定环境分布取期望。此时，“哪个行动最好”必须改写为“面对其他参与者的选择，什么策略能够抵抗偏离或形成稳定响应”。本章沿用三个三张牌的教学博弈。牌面只有高牌、中牌和低牌，实际使用其中一张隐藏牌来决定是否质询、是否应对。这个小牌面会先被压缩成收益矩阵，用于求零和博弈值；随后还原成历史树，说明私人信息为何不能当作普通状态。重复对局时，局部决策会产生遗憾，完全回忆把这些局部遗憾连接到整局偏离。若参与者转为合作，同一个任务又会提出怎样按各方信息分配共同收益的问题。这几类答案不可互换。极小极大值控制最坏对手下的保证，Nash 均衡排除单方有利偏离，相关均衡还要说明看到建议后允许怎样改动；低遗憾是多轮比较结论，不自动说明末次策略收敛；Shapley 值分配预先定义的联盟价值，却不负责证明参与者会自愿采用该分配。本章依次从收益结构、响应稳定性、信息结构、学习过程和合作分配五个方面建立这些边界。

19.1 矩阵博弈与零和对偶

19.1.1 收益由联合行动而不是单方行动决定

有限双人**矩阵博弈** (matrix game) 由两组有限行动 $A_1 = \{1, \dots, m\}$ 、 $A_2 = \{1, \dots, n\}$ 和两张收益矩阵 $U_1, U_2 \in \mathbb{R}^{m \times n}$ 给出。第 1 位参与者选择行，第 2 位参与者选择列，落在 (i, j) 时，两人的收益分别为 $((U_1)_{i,j}, (U_2)_{i,j})$ 。若存在矩阵 M 使 $U_1 = M$ 、 $U_2 = -M$ ，双方收益之和恒为零，就得到**零和博弈** (zero-sum game)。一个人增加的收益正好是另一个人的损失，因此零和情形只需记录第 1 位参与者的收益矩阵 M ；一般和情形则不能省略第二张矩阵。

直接选择某一行或某一列称为**纯策略** (pure strategy)。当纯策略会被对

方针对时，参与者可以在行动上选择概率分布。记

$$\Delta_m = \{\mathbf{x} \in \mathbb{R}^m : \mathbf{x} \geq \mathbf{0}, \mathbf{1}^\top \mathbf{x} = 1\}$$

为 m 个行动上的概率单纯形。它嵌入 $\mathbb{R}^m$ ，几何维数为 $m-1$ 。第 1 位参与者采用 $\mathbf{x} \in \Delta_m$ ，第 2 位参与者采用 $\mathbf{y} \in \Delta_n$ 时，期望收益为

$$u(\mathbf{x}, \mathbf{y}) = \mathbf{x}^\top \mathbf{M} \mathbf{y}. \quad (19.1)$$

混合策略不是在一局内把多个行动平均执行，而是在行动前用随机装置抽取一个纯行动。

给定对手策略后，使自身收益最大的策略称为**最佳响应** (best response)。第 1 位参与者面对 $\mathbf{y}$ 的最佳响应集合为

$$\text{BR}_1(\mathbf{y}) = \arg \max_{\mathbf{x} \in \Delta_m} \mathbf{x}^\top \mathbf{M} \mathbf{y}.$$

线性目标总能在某个纯行动达到最大值，但把全部概率放在一个最佳纯行动上未必是唯一选择；若多行并列，它们的任意混合仍是最佳响应。

19.1.2 匹配硬币说明随机化的作用

考虑双方同时选择正面 H 或反面 T 。两面相同时参与者 1 得到 1，不同时得到 -1，参与者 2 得到相反收益。参与者 1 的收益矩阵为

$$\mathbf{M}_{\text{mp}} = \begin{pmatrix} 1 & -1 \\ -1 & 1 \end{pmatrix}.$$

任意纯策略组合都不是稳定响应：若两面相同，参与者 2 改换一面便能改善；若两面不同，参与者 1 改换一面便能改善。若逐轮对上一轮行动作纯最佳响应，行动还会在四个组合之间循环，这说明“每轮都回应当前对手”不等于联合策略会收敛。

令参与者 1 选择 H 的概率为 p ，参与者 2 选择 H 的概率为 q 。参与者 1 选 H 与 T 的期望收益分别为 $2q-1$ 与 $1-2q$ 。只有 $q=1/2$ 能使两行收益相同，避免参与者 1 利用某一面；对称地，只有 $p=1/2$ 能使参与者 2 无法利用。所以双方均匀随机化时收益为

$$(1/2, 1/2) \mathbf{M}_{\text{mp}} (1/2, 1/2)^\top = 0.$$

这个二乘二例子展示了混合策略的核心作用：随机化不是让某个纯行动变好，而是消除对手针对固定行动获得的优势。

19.1.3 三张牌质询博弈

考虑高牌 H 、中牌 M 和低牌 L 。庄家从 H 与 L 中等概率发给参与者 1 一张隐藏牌， M 留作公共比较基准。参与者 1 看到自己的牌后选择质询 B 或放弃 P 。放弃时收益为 0。质询后，参与者 2 只知道发生了质询，不知道隐藏牌，并选择应对 C 或退让 F 。退让时参与者 1 得到 1；应对时，高牌使参与者 1 得到 2，低牌使其得到 -2 。参与者 2 得到相反收益。

在把信息时序展开以前，可以先把一项纯策略写成“拿到高牌时做什么，拿到低牌时做什么”。按 $(P, P), (B, P), (P, B), (B, B)$ 排列参与者 1 的四个完整计划，按 F, C 排列参与者 2 的行动，参与者 1 的事前期望收益矩阵为

$$M = \begin{pmatrix} 0 & 0 \\ 1/2 & 1 \\ 1/2 & -1 \\ 1 & 0 \end{pmatrix}. \quad (19.2)$$

例如，计划 (B, P) 只在拿到高牌时质询。对方退让时，收益以一半概率为 1、一半概率为 0，故矩阵元素为 $1/2$ ；对方应对时，相应期望为 1。

这个矩阵没有纯策略鞍点。每一行的最小收益依次为 $0, 1/2, -1, 0$ ，故第 1 位参与者先公开选行时至多保证 $1/2$ ；每一列的最大收益分别为 $1, 1$ ，故第 2 位参与者先公开选列时至多把收益压到 1。两种次序得到不同数值，说明任何固定纯行动都会留下可利用的响应。

19.1.4 保证值与极小极大值

第 1 位参与者在不知道对方将怎样响应时，希望最大化自己能够保证的最小收益：

$$\underline{v} = \max_{x \in \Delta_m} \min_{y \in \Delta_n} x^T M y.$$

对固定 x ，第 2 位参与者的目标关于 y 线性，所以最小值在某个纯列达到。因此

$$\min_{y \in \Delta_n} x^T M y = \min_j (M^T x)_j.$$

类似地，第 2 位参与者希望把第 1 位参与者的最大可得收益压低到

$$\bar{v} = \min_{y \in \Delta_n} \max_{x \in \Delta_m} x^T M y = \min_{y \in \Delta_n} \max_i (M y)_i.$$

对任意 x, y ，都有

$$\min_{\tilde{y}} u(x, \tilde{y}) \leq u(x, y) \leq \max_{\tilde{x}} u(\tilde{x}, y).$$

分别对左侧取最大、右侧取最小，得到 $\underline{v} \leq \bar{v}$ 。这只是弱极小极大关系。要

证明有限零和博弈中两者相等，还需要说明双方约束恰好构成一对线性规划。

定理 19.1 有限零和博弈的极小极大定理 对任意有限收益矩阵 $\mathbf{M}$ ，有

$$\max_{\mathbf{x} \in \Delta_m} \min_{\mathbf{y} \in \Delta_n} \mathbf{x}^\top \mathbf{M} \mathbf{y} = \min_{\mathbf{y} \in \Delta_n} \max_{\mathbf{x} \in \Delta_m} \mathbf{x}^\top \mathbf{M} \mathbf{y}. \quad (19.3)$$

共同数值称为博弈值 v^* 。等式两侧的最优解分别称为双方的极小极大策略。

证明. 引入第 1 位参与者要保证的收益下界 v 。条件 $(\mathbf{M}^\top \mathbf{x})_j \geq v$ 对每一列成立，恰好表示任何纯列都不能把收益压到 v 以下。第 1 位参与者的问题因此是

$$\begin{aligned} \max_{\mathbf{x}, v} \quad & v \\ \text{s.t.} \quad & \mathbf{M}^\top \mathbf{x} \geq v \mathbf{1}, \\ & \mathbf{1}^\top \mathbf{x} = 1, \quad \mathbf{x} \geq \mathbf{0}. \end{aligned} \quad (19.4)$$

它的最优值正是 $\underline{v}$ 。为第一组不等式引入非负乘子 $\mathbf{y} \geq \mathbf{0}$ ，为概率归一化引入自由乘子 w 。把最大化问题写成上界形式后，其拉格朗日函数可整理为

$$\mathcal{L}(\mathbf{x}, v; \mathbf{y}, w) = v + \mathbf{y}^\top (\mathbf{M}^\top \mathbf{x} - v \mathbf{1}) + w(1 - \mathbf{1}^\top \mathbf{x}).$$

若对自由变量 v 取上确界仍为有限值，必须有 $\mathbf{1}^\top \mathbf{y} = 1$ 。若对 $\mathbf{x} \geq \mathbf{0}$ 取上确界仍为有限值，还必须有

$$\mathbf{M} \mathbf{y} \leq w \mathbf{1}.$$

满足这些条件时，上确界等于 w 。于是对偶问题为

$$\begin{aligned} \min_{\mathbf{y}, w} \quad & w \\ \text{s.t.} \quad & \mathbf{M} \mathbf{y} \leq w \mathbf{1}, \\ & \mathbf{1}^\top \mathbf{y} = 1, \quad \mathbf{y} \geq \mathbf{0}. \end{aligned} \quad (19.5)$$

它要求每个纯行的收益都不超过 w ，所以最优值正是 $\bar{v}$ 。两个单纯形都非空且紧，目标连续，因此式 (19.4) 与 (19.5) 都有有限最优解。第 3.8 号定理给出原对偶最优值相等，即 $\underline{v} = \bar{v} = v^*$ 。 ■

这个证明不只是交换了 $\max$ 与 $\min$ 。概率归一化把乘子变成对方的混合策略，逐行动收益约束把对偶可行性变成“没有纯行动能突破当前上界”。强对偶才把两种单方证书接成同一个博弈值。

若 $\mathbf{x}^*$ 与 $\mathbf{y}^*$ 分别是两侧最优策略, 则对任意 $\mathbf{x} \in \Delta_m$ 、 $\mathbf{y} \in \Delta_n$,

$$u(\mathbf{x}, \mathbf{y}^*) \leq u(\mathbf{x}^*, \mathbf{y}^*) \leq u(\mathbf{x}^*, \mathbf{y}). \quad (19.6)$$

左侧来自 $\mathbf{y}^*$ 把所有行收益限制在 v^* 以下, 右侧来自 $\mathbf{x}^*$ 对所有列保证至少 v^* 。这就是混合策略上的鞍点条件。博弈值由式 (19.3) 唯一确定, 但达到该值的策略可以不唯一; 把“值唯一”误读成“解唯一”, 会遗漏并列最优行动形成的整个最优策略集合。

19.1.5 用原对偶证书解牌面例子

对式 (19.2), 令第 1 位参与者在计划 (B, P) 与 (B, B) 上分别放置概率 $2/3$ 与 $1/3$, 其余计划概率为零:

$$\mathbf{x}^* = (0, 2/3, 0, 1/3)^\top.$$

面对退让列, 期望收益为

$$\frac{2}{3} \cdot \frac{1}{2} + \frac{1}{3} \cdot 1 = \frac{2}{3};$$

面对应对列, 期望收益为

$$\frac{2}{3} \cdot 1 + \frac{1}{3} \cdot 0 = \frac{2}{3}.$$

所以 $(\mathbf{x}^*, 2/3)$ 是式 (19.4) 的可行解。

再令第 2 位参与者以概率 $2/3$ 退让、以概率 $1/3$ 应对:

$$\mathbf{y}^* = (2/3, 1/3)^\top.$$

四个纯计划对它的收益依次为

$$0, \quad \frac{1}{2} \cdot \frac{2}{3} + 1 \cdot \frac{1}{3} = \frac{2}{3}, \quad \frac{1}{2} \cdot \frac{2}{3} - 1 \cdot \frac{1}{3} = 0, \quad \frac{2}{3}.$$

没有一行超过 $2/3$, 所以 $(\mathbf{y}^*, 2/3)$ 是式 (19.5) 的可行解。弱对偶已经足以说明两者同时最优, 博弈值为 $v^* = 2/3$ 。

从牌面条件看, 这个混合计划等价于: 拿到高牌总是质询, 拿到低牌以概率 $1/3$ 质询; 参与者 2 面对质询时以概率 $1/3$ 应对。高牌的强行动掩护了低牌的偶尔质询, 低牌的存在又使应对者不能总是退让。这个解释依赖参与者 2 看不到牌面; 第 19.3 节会把该信息限制写进历史树。

极小极大结论依赖零和结构。若退让、应对或交易产生了双方并不相反的成本, 就不能再用一个标量博弈值同时概括双方目标。此时仍可讨论最佳响应, 但稳定性必须改用一般和均衡。对于无限或连续行动集, 有限维线性规划证明也不再直接适用; 交换极大与极小通常还需要非空紧凸策略

集、收益连续以及相应的凸凹结构。

19.2 最佳响应与均衡存在

19.2.1 一般和博弈需要逐个参与者检查偏离

有限 n 人**战略式博弈** (strategic-form game) 由参与者集合 $N = \{1, \dots, n\}$ 、每人的有限行动集 A_i 和收益函数

$$u_i : A_1 \times \dots \times A_n \rightarrow \mathbb{R}$$

组成。一般和博弈允许 u_i 与 u_j 同时增加或同时减少, 因此不存在一个天然的“共同博弈值”。记混合策略为 $\sigma_i \in \Delta(A_i)$, 联合策略为 $\sigma = (\sigma_1, \dots, \sigma_n)$, 去掉第 i 项后的组合为 σ_{-i} 。各参与者按照自己的混合策略独立抽取行动, 因此联合行动 $\mathbf{a} = (a_1, \dots, a_n)$ 的概率是 $\prod_{j=1}^n \sigma_j(a_j)$ 。纯行动收益由此延拓为期望收益

$$u_i(\sigma) = \sum_{\mathbf{a} \in A_1 \times \dots \times A_n} \left(\prod_{j=1}^n \sigma_j(a_j) \right) u_i(\mathbf{a}). \quad (19.7)$$

后文沿用 u_i 表示这一延拓。这里的独立抽样产生乘积分布; 相关均衡则允许一般的联合行动分布。

给定其他参与者的策略, 参与者 i 的最佳响应对应为

$$\text{BR}_i(\sigma_{-i}) = \arg \max_{\tilde{\sigma}_i \in \Delta(A_i)} u_i(\tilde{\sigma}_i, \sigma_{-i}).$$

这里使用“对应”而不是“函数”, 因为多个行动可能并列最优。

定义 19.2 Nash 均衡 联合混合策略 σ^* 是一个 **Nash 均衡** (Nash equilibrium), 若对每个参与者 i 和任意替代策略 $\tilde{\sigma}_i$, 都有

$$u_i(\sigma_i^*, \sigma_{-i}^*) \geq u_i(\tilde{\sigma}_i, \sigma_{-i}^*). \quad (19.8)$$

这一定义只排除单方偏离。它不要求总收益最大, 不排除多个参与者联合偏离, 也不比较不同均衡的公平性。在牌桌上, 若两位工作人员都可以付出成本核验牌面, 一方核验时另一方可能选择搭便车; “无人能独自改进”并不等于“核验资源使用得最少”或“双方收益最高”。

零和博弈中的一对极小极大策略构成 Nash 均衡。反过来, 任何零和 Nash 均衡都给出相同博弈值, 因为一方偏离条件分别给出鞍点不等式

$$u(\mathbf{x}, \mathbf{y}^*) \leq u(\mathbf{x}^*, \mathbf{y}^*) \leq u(\mathbf{x}^*, \mathbf{y}).$$

一般和博弈没有这个共同数值，不同均衡还可能给每位参与者带来不同收益。

19.2.2 从连续不动点到集合值响应

若每个最佳响应都是唯一且连续的，就可以把所有人的响应拼成映射

$$B(\sigma) = (BR_1(\sigma_{-1}), \dots, BR_n(\sigma_{-n})),$$

再寻找 $B(\sigma) = \sigma$ 。实际博弈常在收益并列处有多个最佳响应， B 因而不是单值连续函数。强行规定“并列时选编号最小的行动”会造成跳跃，不能直接应用 Brouwer 不动点定理。

引理 19.3 Sperner 引理 把 d 维标准单纯形

$$\Delta^d = \{x \in \mathbb{R}^{d+1} : x \geq 0, 1^T x = 1\}$$

有限剖分成小单纯形。若每个剖分顶点的标签属于 $\{0, \dots, d\}$ ，并且位于由顶点集合 S 张成的面上的点只能使用 S 中的标签，则同时含有全部 $d+1$ 种标签的小单纯形有奇数个，因而至少存在一个。

证明. 对维数 d 归纳。 $d=1$ 时，线段两个端点分别只能标 0 与 1。沿剖分顶点从左向右读取标签，每次改变对应一条含有两种标签的小线段；由于起点为 0、终点为 1，改变次数为奇数。

先在 $d=2$ 的三角形中看清高维计数。三条边上的剖分顶点只能使用相应两个端点的标签。例如，顶点 0 与 1 之间的边只能标 0 或 1，一维情形说明这条边上含两种标签的小边有奇数条。计数所有带标签 0,1 的小边与小三角形的邻接：内部小边被两个小三角形共享，贡献两次；大三角形边界上的小边只邻接一个小三角形，而带齐 0,1 的边界小边只能出现在刚才的 0,1 边上。一个全标号小三角形恰有一条 0,1 边，只含标签 0,1 且两种标签都出现的小三角形有两条这样的边，其余小三角形没有。因此邻接总数为奇数迫使全标号小三角形的数量为奇数。一般维证明把“小边”换成余维一的小面，把“小三角形”换成小单纯形。

假设结论对 $d-1$ 维成立。在全部 d 维小单纯形中，计数标签集合恰为 $\{0, \dots, d-1\}$ 的 $(d-1)$ 维面与小单纯形的邻接次数。内部面邻接两个小单纯形，贡献偶数；边界面只邻接一个小单纯形。边界上只有大单纯形的 $x_d = 0$ 面可能出现全部标签 $0, \dots, d-1$ ，因为其他边界面缺少其中某个允许标签。该面继承 Sperner 标号，归纳假设说明其中这类小面有奇数个。因此总邻接次数为奇数。

一个 d 维小单纯形若含有全部标签 $0, \dots, d$ ，恰有一个面带齐 $0, \dots, d-1$ ，

即去掉标签 d 顶点所得的面。若它没有标签 d , 却带齐 $0, \dots, d-1$, 则 $d+1$ 个顶点中恰有一个标签重复, 去掉任一重复标签顶点都会得到这样的面, 所以贡献两次; 其余小单纯形贡献零次。总邻接次数的奇偶性因而等于全标号小单纯形数目的奇偶性。前者为奇数, 后者至少为一。 ■

定理 19.4 Brouwer 不动点定理 若 $K \subseteq \mathbb{R}^d$ 非空、紧且凸, 则每个连续映射 $f: K \rightarrow K$ 至少有一个不动点。

证明. 先令 $K = \Delta^d$. 取网格直径趋于零的一列单纯形剖分。若某个剖分顶点 $\mathbf{x}$ 已经满足 $f(\mathbf{x}) = \mathbf{x}$, 结论成立; 否则因为 $\sum_j x_j = \sum_j f_j(\mathbf{x}) = 1$, 至少存在一个坐标 j 满足 $x_j > f_j(\mathbf{x})$, 任选这样的 j 作为标签。若 $x_j = 0$, 这个严格不等式不可能成立, 所以边界标号满足引理 19.3 的条件。

每个剖分因而都有一个全标号小单纯形。对第 k 次剖分, 记其中标签为 j 的顶点为 $\mathbf{x}_{k,j}$ 。由紧性可取子列, 使 $\mathbf{x}_{k,0} \rightarrow \mathbf{x}^*$; 小单纯形直径趋于零, 所以每个 $\mathbf{x}_{k,j}$ 都趋于同一个 $\mathbf{x}^*$ 。标签定义和连续性给出

$$x_j^* \geq f_j(\mathbf{x}^*), \quad j = 0, \dots, d.$$

两边坐标和都为 1, 故所有不等式只能同时取等号, $f(\mathbf{x}^*) = \mathbf{x}^*$ 。

对一般的非空紧凸集 K , 取一个包含 K 的有限维单纯形 S , 并记 $\Pi_K: S \rightarrow K$ 为到闭凸集 K 的欧氏投影。映射 $g = f \circ \Pi_K: S \rightarrow K \subseteq S$ 连续, 前一部分给出 $\mathbf{x}^* = g(\mathbf{x}^*)$ 。右侧属于 K , 所以 $\mathbf{x}^* \in K$ 且 $\Pi_K(\mathbf{x}^*) = \mathbf{x}^*$, 进而 $f(\mathbf{x}^*) = \mathbf{x}^*$ 。 ■

在区间上, 这个结论退化为对 $f(x) - x$ 使用介值性质; 高维中没有统一的“左右端点”, Sperner 引理用边界相容标号和奇偶计数补上了这一步。Brouwer 只保证不动点存在, 不要求映射压缩, 因此既不保证不动点唯一, 也不保证反复应用 f 会收敛。

需要的替代对象是**集合值映射** (correspondence) $F: K \rightrightarrows K$, 它把一点映到一个非空集合。若 $F(x)$ 不会在 x 发生微小变化时突然出现远处的新值, 就称它**上半连续** (upper hemicontinuous)。在紧值情形, 一个便于使用的等价判据是闭图性质:

$$x_k \rightarrow x, \quad y_k \rightarrow y, \quad y_k \in F(x_k) \implies y \in F(x).$$

闭图判据适用于后面的有限博弈, 因为定义域和值域都位于有限维紧集。

例如, 对手以概率 q 选择左列, 而某参与者的两个行动收益分别为 q 和

$1 - q$ 时, 其最佳响应对应为

$$\text{BR}(q) = \begin{cases} \{\text{左}\}, & q > 1/2, \\ \Delta(\{\text{左}, \text{右}\}), & q = 1/2, \\ \{\text{右}\}, & q < 1/2. \end{cases}$$

在 $q = 1/2$ 强行挑一个行动会造成单值选择跳跃; 保留整段混合策略后, 对应的值仍非空、紧且凸, 并且极限不会跳出图。这正是 Kakutani 定理保留并列响应的方式。

下面使用的多值映射不动点结论源于 Kakutani 定理¹。

定理 19.5 Kakutani 不动点定理 设 $K \subseteq \mathbb{R}^d$ 非空、紧且凸。若 $F : K \rightrightarrows K$ 上半连续, 并且每个 $F(x)$ 都非空、紧且凸, 则存在 $x^* \in K$ 满足 $x^* \in F(x^*)$ 。

¹ S. Kakutani, *A Generalization of Brouwer's Fixed Point Theorem* In *Duke Mathematical Journal*, 1941, vol. 8, no. 3, pp. 457–459

下面用单纯形细分和重心插值, 把集合值映射转为 Brouwer 定理能够处理的连续映射。

引理 19.6 单纯形上的连续近似选择 在定理 19.5 的条件下, 取一个包含 K 的单纯形 $S \subseteq \mathbb{R}^d$, 并记到 K 的欧氏投影为 $\Pi_K : S \rightarrow K$ 。对每个 $\varepsilon > 0$, 存在连续映射 $f_\varepsilon : S \rightarrow K$, 使每个 $x \in S$ 都有 $x' \in S$ 及 $y \in F(\Pi_K(x'))$ 满足

$$\|x - x'\|_2 + \|f_\varepsilon(x) - y\|_2 < \varepsilon.$$

证明. 对 S 取一系列网格直径趋于零的有限单纯形细分。固定第 k 次细分; 对每个网格顶点 $\mathbf{v}$, 从非空集合 $F(\Pi_K(\mathbf{v}))$ 中任选一点 $\mathbf{y}_{\mathbf{v}}$ 。若 $\mathbf{x}$ 位于顶点为 $\mathbf{v}_0, \dots, \mathbf{v}_d$ 的一个小单纯形内, 把它写成重心坐标

$$\mathbf{x} = \sum_{j=0}^d \lambda_j \mathbf{v}_j, \quad \lambda_j \geq 0, \quad \sum_{j=0}^d \lambda_j = 1,$$

并定义

$$f_k(\mathbf{x}) = \sum_{j=0}^d \lambda_j \mathbf{y}_{\mathbf{v}_j}.$$

相邻小单纯形在公共面上使用相同的顶点值, 所以这些仿射片段拼成连续映射。又因 K 凸, 每个 $f_k(\mathbf{x})$ 都属于 K 。

在乘积空间上使用 $\|(\mathbf{x}, \mathbf{y})\| = \|\mathbf{x}\|_2 + \|\mathbf{y}\|_2$ 。下面说明网格变细时,

$(\mathbf{x}, f_k(\mathbf{x}))$ 会一致逼近对应

$$\tilde{F}(\mathbf{x}) = F(\Pi_K(\mathbf{x}))$$

的图。否则存在 $\varepsilon_0 > 0$ 和点 $\mathbf{x}_k \in S$, 使这些点到 $\text{graph}(\tilde{F})$ 的距离始终至少为 ε_0 。取包含 $\mathbf{x}_k$ 的小单纯形及其顶点 $\mathbf{v}_{k,0}, \dots, \mathbf{v}_{k,d}$ 。由 S 与 K 的紧性, 可沿一个子列令 $\mathbf{x}_k \rightarrow \mathbf{x}$ 、各重心系数收敛, 并令所选的 $\mathbf{y}_{k,j} \in F(\Pi_K(\mathbf{v}_{k,j}))$ 逐项收敛到 $\mathbf{y}_j$ 。网格直径趋于零, 所以每个 $\mathbf{v}_{k,j} \rightarrow \mathbf{x}$; 投影连续和 F 的闭图性质于是给出

$$\mathbf{y}_j \in F(\Pi_K(\mathbf{x})).$$

值集的凸性进一步说明重心极限 $\mathbf{y} = \sum_j \lambda_j \mathbf{y}_j$ 仍属于 $F(\Pi_K(\mathbf{x}))$ 。另一方面, $f_k(\mathbf{x}_k) \rightarrow \mathbf{y}$, 这与到图的距离保持在 ε_0 以上矛盾。因此充分细的网格给出所需 f_ε 。 ■

定理 19.5 的证明. 对 $\varepsilon_k \downarrow 0$, 由引理 19.6 得到连续映射 $f_k : S \rightarrow K \subseteq S$ 。Brouwer 不动点定理说明存在 $x_k \in S$ 使 $x_k = f_k(x_k)$; 由于右侧属于 K , 每个 x_k 其实都在 K 中。 K 紧, 所以某个子列收敛到 $x^* \in K$ 。

近似选择性质给出 $x'_k \in S$ 与 $y_k \in F(\Pi_K(x'_k))$, 使 $\|x_k - x'_k\|_2 + \|x_k - y_k\|_2 \rightarrow 0$ 。因此同一子列上 $\Pi_K(x'_k) \rightarrow x^*$ 且 $y_k \rightarrow x^*$ 。 F 具有闭图, 于是

$$x^* \in F(x^*).$$

细分和重心插值把集合值问题变成连续单值问题, Brouwer 提供近似不动点, 紧性提供收敛子列, 闭图性质再把极限送回 F 。 ■

19.2.3 有限博弈的 Nash 存在性

Nash 的不动点论证给出有限博弈的基本存在性结果²。

定理 19.7 有限博弈存在混合 Nash 均衡 每个参与者和每个行动集都有限的战略式博弈至少存在一个混合策略 Nash 均衡。

证明. 联合混合策略空间

$$K = \prod_{i=1}^n \Delta(A_i)$$

是有限维非空紧凸集。定义联合最佳响应对应

$$F(\sigma) = \prod_{i=1}^n \text{BR}_i(\sigma_{-i}).$$

对固定 σ_{-i} , 收益关于 σ_i 连续, 而概率单纯形紧, 所以最大值达到, BR_i 非空且紧。收益关于自身混合策略线性, 两个最佳响应的凸组合仍达到同

² J. Nash, *Non-Cooperative Games* In *The Annals of Mathematics*, 1951, vol. 54, no. 2, pp. 286–295

一最大值, 所以最佳响应值集是凸集。

还需核对闭图。设 $\sigma^{(k)} \rightarrow \sigma$, 并且 $\tau_i^{(k)} \rightarrow \tau_i$, 其中 $\tau_i^{(k)} \in \text{BR}_i(\sigma_{-i}^{(k)})$ 。对任意固定替代策略 $\tilde{\sigma}_i$, 最佳响应性质给出

$$u_i(\tau_i^{(k)}, \sigma_{-i}^{(k)}) \geq u_i(\tilde{\sigma}_i, \sigma_{-i}^{(k)}).$$

有限博弈的期望收益是混合概率的多线性函数, 因而连续。令 $k \rightarrow \infty$, 得到

$$u_i(\tau_i, \sigma_{-i}) \geq u_i(\tilde{\sigma}_i, \sigma_{-i}).$$

这对所有替代策略成立, 故 $\tau_i \in \text{BR}_i(\sigma_{-i})$ 。每个分量都具有闭图, 有限乘积 F 也上半连续。

定理 19.5 给出 $\sigma^* \in F(\sigma^*)$ 。逐分量展开正是 $\sigma_i^* \in \text{BR}_i(\sigma_{-i}^*)$, 也就是式 (19.8)。 ■

存在性没有给出唯一性、计算效率或学习动态收敛。即便收益矩阵很小, 最佳响应也可能在多个均衡之间切换; 在“石头、剪刀、布”一类循环响应中, 逐轮选择当前最佳纯行动甚至不会收敛。第 2 章的压缩映射同时给出唯一不动点与迭代收敛, 而 Kakutani 只在更弱条件下给出至少一个不动点。这两种结论服务于不同问题。

19.2.4 相关建议改变了允许偏离的时机

Nash 均衡要求各人的随机化彼此独立。若一个公共装置先抽取联合行动 $\mathbf{A} \sim \mu$, 再分别向参与者发送建议, 建议之间可以相关。关键问题变成: 参与者在看到自己的建议以后, 是否愿意按建议行动。

分布 μ 是**粗相关均衡** (coarse correlated equilibrium, CCE), 若对每个参与者 i 和任意固定行动 a'_i ,

$$\mathbb{E}_{\mathbf{A} \sim \mu}[u_i(\mathbf{A})] \geq \mathbb{E}_{\mathbf{A} \sim \mu}[u_i(a'_i, \mathbf{A}_{-i})]. \quad (19.9)$$

偏离者必须在看到建议之前承诺改用同一个固定行动。若允许他看到建议 A_i 后按映射 $\phi_i(A_i)$ 改动, 则要求

$$\mathbb{E}_{\mathbf{A} \sim \mu}[u_i(\mathbf{A})] \geq \mathbb{E}_{\mathbf{A} \sim \mu}[u_i(\phi_i(A_i), \mathbf{A}_{-i})] \quad (19.10)$$

对所有映射 $\phi_i: A_i \rightarrow A_i$ 成立, 这定义**相关均衡** (correlated equilibrium, CE)。

在有限行动集上, CE 条件等价于对每对 $a_i, a'_i \in A_i$ 要求

$$\sum_{\mathbf{a}_{-i}} \mu(a_i, \mathbf{a}_{-i}) [u_i(a_i, \mathbf{a}_{-i}) - u_i(a'_i, \mathbf{a}_{-i})] \geq 0. \quad (19.11)$$

它把“收到 a_i 建议后改成 a'_i ”的条件收益比较乘上收到该建议的概率，因此 $\mu(A_i = a_i) = 0$ 时无需另外定义条件概率。CCE 则把求和扩到全部 a_i ，对应参与者在看见建议前就承诺使用固定的 a'_i 。这些都是关于 μ 的线性不等式，所以有限博弈的 CE 与 CCE 集合都是凸多面体。

相关均衡排除的偏离更丰富，所以每个 CE 都是 CCE，反向不一定成立。独立乘积分布形式的 Nash 均衡又是 CE 的特例。这个包含关系来自允许偏离的信息和时机，而不是来自三个名称的“强弱等级”。具体地说，固定偏离是映射偏离的特例，所以 CE 条件蕴含 CCE 条件；在 Nash 乘积分布中，对手行动与自己的建议独立，而自身混合策略支持集中的每个行动都是对 σ_{-i} 的最佳响应，故观察建议后改用任何行动都不能提高收益。

一个二行动协调博弈可以显示相关分布与独立随机化的差别。双方都选 L 或都选 R 时各得 2，行动不同时各得 0。独立地以 $1/2$ 选择两项是一个混合 Nash 均衡，每人期望收益为 1。公共装置若以 $1/2$ 推荐 (L, L) 、以 $1/2$ 推荐 (R, R) ，每人期望收益为 2，并且看到任一建议后偏离都会把收益降为 0，所以该分布是 CE。它不是两个边缘分布的乘积，但只是相对于上述独立混合均衡改善共同收益；该博弈的两个纯 Nash 均衡本来也各给双方收益 2，CE 并不保证优于每个 Nash 均衡。第 19.4 节会看到，外部遗憾自然对应 CCE，内部或交换遗憾才对应 CE。

19.3 扩展式博弈与信息结构

19.3.1 历史树同时记录行动次序和可用信息

收益矩阵把每人的完整计划一次列出，却隐藏了行动发生的时刻以及当时知道什么。**扩展式博弈**（extensive-form game）用历史树保留这些信息。记 H 为有限历史集合，空历史为 $\emptyset$ 。它满足前缀封闭：若一串行动属于 H ，删去末尾若干行动所得的前缀仍属于 H 。不能再延长的历史组成终止集合 $Z \subset H$ 。若 $h \notin Z$ ，可选行动集合 $A(h)$ 规定合法后继 ha ，参与者函数 $P(h)$ 指出下一步由哪位参与者行动；机会节点记为 $P(h) = c$ ，其行动概率 $\sigma_c(a | h)$ 已给定且在 $A(h)$ 上和为 1。终止历史 z 为每位参与者给出收益 $u_i(z)$ 。

三张牌质询博弈的机会节点先选择 H 或 L ，概率各为 $1/2$ 。参与者 1 看到牌面，所以“拿到 H ”与“拿到 L ”属于两个不同决策位置。若他选择 P ，历史立即终止；若选择 B ，参与者 2 行动。参与者 2 只看到“发生了质询”，无法区分历史 (H, B) 与 (L, B) 。

对参与者 i ，记全部由其行动的非终止历史为

$$H_i = \{h \in H \setminus Z : P(h) = i\}.$$

参与者 i 的**信息集** (information set) 族 $\mathcal{I}_i$ 是 H_i 的一个划分, 每个信息集 $I \in \mathcal{I}_i$ 收集参与者当时无法区分的决策历史。同一信息集中的历史必须具有相同的合法行动集, 记这个共同集合为 $A(I) = A(h)$, 其中 $h \in I$; 否则参与者连“现在能做什么”都无法由观察确定。牌面例子中, 参与者 2 的信息集为

$$I_2 = \{(H, B), (L, B)\},$$

可选行动都是 $\{C, F\}$ 。信息集不是状态的另一名称。第 17.3 节中的 Markov 状态用于预测给定行动后的未来分布; 信息集描述当前参与者无法区分哪些历史。两个节点可以有相同物理状态, 却因参与者记得不同过去而属于不同信息集, 也可以物理状态不同却因观察受限而位于同一信息集。参与者 i 的纯策略必须为每个 $I \in \mathcal{I}_i$ 指定一个 $A(I)$ 中的行动, 包括均衡路径上不会到达的信息集; 因此它是一份完整的应急计划, 而不只是实际走过路径上的动作序列。

19.3.2 行为策略、混合策略与完全回忆

参与者 i 的**行为策略** (behavior strategy) $\sigma_i(a | I)$ 在每个信息集 $I \in \mathcal{I}_i$ 上分别给出行动分布。三张牌例子可写成三个数:

$$b_H = \sigma_1(B | I_H), \quad b_L = \sigma_1(B | I_L), \quad c = \sigma_2(C | I_2).$$

第 19.1 节得到的均衡对应

$$b_H^* = 1, \quad b_L^* = \frac{1}{3}, \quad c^* = \frac{1}{3}.$$

战略式中的混合策略是在游戏开始时随机抽取一个完整纯计划; 行为策略则在每个信息集到达时随机选择。二者在一般情形下并不等价。若参与者会忘记自己早先知道的牌或采取的行动, 开局抽取的同一个随机计划可以在多个时刻制造相关性, 而独立的局部随机化未必能复制这种相关性。

完全回忆 (perfect recall) 要求参与者在同一信息集内不能混淆自己过去获得的信息和采取的行动。更具体地说, 任意两个属于同一信息集的历史, 沿途经过的该参与者信息集序列及其本人行动序列必须相同。

定理 19.8 Kuhn 实现等价 在有限完全回忆扩展式博弈中, 对任一参与者, 任意混合策略都存在一个行为策略, 使二者面对任意固定的对手与机会策略时诱导相同的终止历史分布; 任意行为策略也存在具有同样性质的混合策略。

证明. 先从混合策略构造行为策略。设 μ_i 是在有限纯策略集合上的分布。

完全回忆保证每个信息集 I 都有唯一的本人前缀

$$\rho_i(I) = ((I_1, a_1), \dots, (I_k, a_k)),$$

即到达 I 以前本人依次经过的信息集和采取的行动；同一 I 中的所有历史共享这条前缀。记 E_I 为纯策略与这条前缀一致的事件。若 $\mu_i(E_I) > 0$ ，定义

$$\sigma_i(a | I) = \frac{\mu_i(E_I \cap \{s_i : s_i(I) = a\})}{\mu_i(E_I)},$$

其中 s_i 表示一项完整纯策略，事件 $s_i(I) = a$ 表示它在当前信息集指定行动 a ；若分母为零，就在 $A(I)$ 上任取一个分布。

沿任意终止历史依次考察参与者 i 的行动。链式法则表明， μ_i 抽取的完整计划与这条本人行动序列一致的概率，等于上述各条件概率的乘积，也就是行为策略 σ_i 沿该历史贡献的到达概率。对手与机会的路径概率在两种表示下相同，所以每个终止历史的总概率相同。分母为零的信息集只位于 μ_i 赋予零概率的本人前缀之后，任意补全都不改变这一结论。

反过来，给定行为策略 σ_i ，在游戏开始前为每个信息集独立抽取一个行动，并把全部抽取结果组成纯策略 s_i 。令

$$\mu_i(s_i) = \prod_{I \in \mathcal{I}_i} \sigma_i(s_i(I) | I).$$

对任意终止历史，把未出现在该历史上的信息集行动求和后都得到因子 1，剩余因子恰是行为策略沿该历史的行动概率乘积。因此该混合策略面对任意对手与机会策略，也诱导与原行为策略相同的终止历史分布。 ■

完全回忆不能省略。考虑一位参与者先在 I_1 选择 L 或 R ，随后到达同一个信息集 I_2 ，却忘记了刚才的选择，并在 I_2 选择 l 或 r 。混合策略可以各以 $1/2$ 抽取完整计划 (L, l) 与 (R, r) ，只产生 Ll 和 Rr 两条历史。任何行为策略若让第一步的 L, R 都以正概率出现，且让第二步的 l, r 也都以正概率出现，就还会以正概率产生 Lr 和 Rl ；若把某个概率设为零，又无法同时保留前两条历史各 $1/2$ 的概率。因此局部独立随机化不能复现混合计划中的跨时相关性。

牌面例子满足完全回忆。参与者 1 只行动一次，参与者 2 也只有一个信息集行动，不存在忘记自身观察或动作的机会。矩阵混合 (B, P) 概率 $2/3$ 、 (B, B) 概率 $1/3$ ，在高牌信息集总是选择 B ，在低牌信息集以概率 $1/3$ 选择 B ，正好得到上述行为策略。

19.3.3 到达概率需要按参与者拆开

给定联合行为策略 σ ，历史

$$h = (a_1, \dots, a_k)$$

的**到达概率** (reach probability) 是沿路径各次行动概率之积。把机会也看作固定策略，可以写成

$$\pi^\sigma(h) = \pi_i^\sigma(h) \pi_{-i}^\sigma(h), \quad (19.12)$$

其中 $\pi_i^\sigma(h)$ 只乘参与者 i 在路径上的行动概率， $\pi_{-i}^\sigma(h)$ 则乘其他参与者与机会的概率。这个分解不会声称两部分随机变量独立；它只是把同一条路径上的乘积按行动者归组。

从历史 h 继续到终止历史 z 的条件路径概率记为 $\pi^\sigma(h, z)$ 。参与者 i 在信息集 I 采取行动 a 的**反事实价值** (counterfactual value) 定义为

$$v_i^\sigma(I, a) = \sum_{h \in I} \pi_{-i}^\sigma(h) \sum_{z \geq ha} \pi^\sigma(ha, z) u_i(z). \quad (19.13)$$

信息集当前策略的反事实价值为

$$v_i^\sigma(I) = \sum_{a \in A(I)} \sigma_i(a | I) v_i^\sigma(I, a). \quad (19.14)$$

式 (19.13) 保留对手和机会到达 I 的权重，却去掉参与者 i 自己在到达 I 以前的概率。它在问：假设参与者 i 把自己送到这个信息集，其他方和机会以当前方式到达各节点时，当前行动价值如何。去掉自身到达权重使一个很少被当前自身策略访问的信息集仍能积累学习信号。

在均衡牌面策略下，参与者 2 的信息集包含高牌质询与低牌质询两个节点。对参与者 2 而言，相应反事实到达权重为

$$\frac{1}{2} b_H^* = \frac{1}{2}, \quad \frac{1}{2} b_L^* = \frac{1}{6}.$$

若把它们归一化，得到到达信息集后的信念

$$\mathbb{P}(H | B) = \frac{3}{4}, \quad \mathbb{P}(L | B) = \frac{1}{4}.$$

后验概率用于该信息集内的条件决策，反事实价值则保留未归一化权重，以便把不同信息集的局部偏离加回整局收益。两者只差一个到达概率因子，却服务于不同推导。

19.3.4 信息结构决定哪些偏离可实施

参与者 2 不能规定“看到高牌质询时应对，看到低牌质询时退让”，因为两个历史位于同一信息集。一个策略偏离必须对信息集中的所有节点采用同一行动分布。若额外公开牌面， I_2 会拆成两个单点信息集，允许偏离集合扩大，原均衡也随之改变。信息增加不只是改善概率估计，它还改变可实施策略的定义域。

未以正概率到达的信息集会带来信念边界。Nash 均衡检查完整策略中的单方偏离，但不要求每个零概率信息集上的信念都由 Bayes 公式唯一决定。若要分析序贯理性，需要进一步规定扰动、信念一致性或更精细的均衡概念。本章只保留后续遗憾分解所需的完全回忆和到达概率，不把 Nash 存在性扩写成所有动态精炼结论。

这里的“反事实”也不同于第 12 章的因果反事实。因果反事实固定同一单位的外生背景，再替换结构方程中的行动；反事实价值则人为去掉某位参与者的自身到达概率，以衡量信息集上的策略偏离。两者都讨论“没有实际发生的另一选择”，但概率空间、固定对象和识别问题并不相同。

19.4 遗憾与反事实分解

19.4.1 遗憾把重复决策与一个比较类相连

设同一参与者连续进行 T 轮决策。第 t 轮选择行动 a_t ，并面对损失函数 $\ell_t: A \rightarrow \mathbb{R}$ 。相对于事后最佳固定行动的 **外部遗憾** (external regret) 为

$$R_{\text{ext}}^T = \max_{a \in A} \sum_{t=1}^T (\ell_t(a_t) - \ell_t(a)). \quad (19.15)$$

若 $R_{\text{ext}}^T/T \rightarrow 0$ ，平均每轮损失渐近不高于任何一个始终使用的固定行动。比较对象不是每轮都知道 ℓ_t 后重新选择的动态先知；后者通常能取得更小损失，也需要额外的变化预算或可预测性假设。

内部遗憾 (internal regret) 允许把每次实际选择 a 的轮次统一替换成另一行动 b ：

$$R_{a \rightarrow b}^T = \sum_{t=1}^T \mathbb{I}\{a_t = a\} (\ell_t(a) - \ell_t(b)).$$

所有这类替换的正遗憾都很小，意味着参与者看到“原本要选 a ”这一信号后，也不愿系统地改成 b 。这正对相关均衡中依赖建议的偏离；外部遗憾只对应粗相关均衡中的固定偏离。

19.4.2 投影更新的累计遗憾界

第 3.9 节的投影不只用于离线优化，也能控制在线累计损失³。设 $C \subseteq \mathbb{R}^d$

³ M. Zinkevich, *Online Convex Programming and Generalized Infinitesimal Gradient Ascent* In Proceedings of the Twentieth International Conference on Machine Learning, 2003, pp. 928–936

为非空闭凸集, 直径至多为 $D \geq 0$, 即对任意 $\mathbf{u}, \mathbf{v} \in C$ 都有 $\|\mathbf{u} - \mathbf{v}\|_2 \leq D$ 。给定轮数 $T \geq 1$ 和步长 $\eta > 0$, 第 t 轮在选择 $\mathbf{w}^{(t)} \in C$ 后观察凸损失 f_t , 取次梯度 $\mathbf{g}^{(t)} \in \partial f_t(\mathbf{w}^{(t)})$, 并假设 $\|\mathbf{g}^{(t)}\|_2 \leq G$, 其中 $G \geq 0$ 。在线投影次梯度更新为

$$\mathbf{w}^{(t+1)} = \Pi_C(\mathbf{w}^{(t)} - \eta \mathbf{g}^{(t)}). \quad (19.16)$$

定理 19.9 在线投影次梯度的外部遗憾 对任意比较点 $\mathbf{w} \in C$, 更新 (19.16) 满足

$$\sum_{t=1}^T (f_t(\mathbf{w}^{(t)}) - f_t(\mathbf{w})) \leq \frac{D^2}{2\eta} + \frac{\eta G^2 T}{2}. \quad (19.17)$$

当 $D > 0$ 且 $G > 0$ 时, 取 $\eta = D/(G\sqrt{T})$, 右侧为 $DG\sqrt{T}$ 。若 $D = 0$, 则 C 只有一个点; 若 $G = 0$, 次梯度不等式说明每轮差值都不大于零。两种退化情形的遗憾上界均为零, 无需使用这个步长公式。

证明. 欧氏投影不会增加到任意可行点的距离, 所以

$$\begin{aligned} \|\mathbf{w}^{(t+1)} - \mathbf{w}\|_2^2 &\leq \|\mathbf{w}^{(t)} - \eta \mathbf{g}^{(t)} - \mathbf{w}\|_2^2 \\ &= \|\mathbf{w}^{(t)} - \mathbf{w}\|_2^2 - 2\eta \langle \mathbf{g}^{(t)}, \mathbf{w}^{(t)} - \mathbf{w} \rangle + \eta^2 \|\mathbf{g}^{(t)}\|_2^2. \end{aligned}$$

凸函数的次梯度不等式给出

$$f_t(\mathbf{w}^{(t)}) - f_t(\mathbf{w}) \leq \langle \mathbf{g}^{(t)}, \mathbf{w}^{(t)} - \mathbf{w} \rangle.$$

把内积从距离展开式中解出并代入, 得到

$$f_t(\mathbf{w}^{(t)}) - f_t(\mathbf{w}) \leq \frac{\|\mathbf{w}^{(t)} - \mathbf{w}\|_2^2 - \|\mathbf{w}^{(t+1)} - \mathbf{w}\|_2^2}{2\eta} + \frac{\eta G^2}{2}.$$

对 t 求和后, 距离平方项望远镜消去, 只剩初始距离上界 D^2 , 得到式 (19.17)。当 $D, G > 0$ 时, 对右侧关于 η 配平即得 $DG\sqrt{T}$; 退化情形按定理后的说明处理。 ■

这个证明允许损失序列依赖过去行动, 只要当前行动在当前损失揭晓前确定。它给出 $O(\sqrt{T})$ 累计遗憾和 $O(T^{-1/2})$ 平均遗憾, 却没有声称 $\mathbf{w}^{(t)}$ 本身收敛。把低遗憾用于博弈时, 通常得到经验分布或平均策略的结论。

概率单纯形把这个通用更新接回混合策略。设行动集为 $A = \{B, P\}$, 取 $C = \Delta(A)$, 并令第 t 轮两个行动的损失向量为 $\boldsymbol{\ell}^{(t)}$ 。分布 $\mathbf{w} \in C$ 的期望损失

$$f_t(\mathbf{w}) = \langle \mathbf{w}, \boldsymbol{\ell}^{(t)} \rangle$$

是线性函数, 次梯度就是 $\boldsymbol{\ell}^{(t)}$ 。若 $\mathbf{w}^{(t)} = (1/2, 1/2)^\top$ 、 $\boldsymbol{\ell}^{(t)} = (0, 1)^\top$ 且

$\eta = 1/2$, 则

$$\Pi_{\Delta(A)}(\mathbf{w}^{(t)} - \eta \mathbf{e}^{(t)}) = (3/4, 1/4)^\top.$$

投影把概率从本轮损失较大的 P 移向 B , 同时保持坐标非负且和为 1。定理因而说明混合策略空间上可以构造局部无外部遗憾更新。下面的 CFR 在各信息集采用遗憾匹配, 而不是必须采用欧氏投影; 这里的通用结果用于建立两类更新共享的无遗憾目标。

19.4.3 信息集上的即时反事实遗憾

前两小节采用损失约定, 遗憾写成实际损失减替代损失。扩展式博弈沿用收益函数, 下面改用收益约定, 把遗憾写成替代收益减当前收益; 令损失等于收益的相反数, 就能在两种约定之间转换, 正遗憾始终表示偏离更有利。

在第 t 轮扩展式博弈中, 联合策略记为 $\sigma^{(t)}$ 。参与者 i 在信息集 I 把当前随机行动改成固定行动 a 的即时反事实遗憾为

$$r_i^{(t)}(I, a) = v_i^{\sigma^{(t)}}(I, a) - v_i^{\sigma^{(t)}}(I). \quad (19.18)$$

累计量及其正部最大值记为

$$R_i^T(I, a) = \sum_{t=1}^T r_i^{(t)}(I, a), \quad R_{i,+}^T(I) = \max \left\{ 0, \max_{a \in A(I)} R_i^T(I, a) \right\}.$$

反事实遗憾最小化 (counterfactual regret minimization, CFR) 在每个信息集运行一个局部无遗憾算法⁴。一次完整树更新包含四步: 固定本轮联合行为策略并遍历历史树, 计算各信息集的反事实行动价值; 用式 (19.18) 累计每个行动的遗憾; 用局部遗憾匹配生成下一轮策略; 同时按本人的到达概率累计平均策略所需的实现权重。这里的“最小化”是让平均遗憾趋近于零, 不是逐轮直接最小化某个静态目标。

⁴ M. Zinkevich, M. Johanson, M. Bowling, C. Piccione, *Regret Minimization in Games with Incomplete Information* In *Advances in Neural Information Processing Systems*, 2007, pp. 1729–1736

典型的**遗憾匹配** (regret matching) 按正累计遗憾选择下一轮行动:

$$\sigma_i^{(t+1)}(a | I) = \begin{cases} \frac{[R_i^t(I, a)]_+}{\sum_b [R_i^t(I, b)]_+}, & \sum_b [R_i^t(I, b)]_+ > 0, \\ \frac{1}{|A(I)|}, & \text{否则.} \end{cases} \quad (19.19)$$

若存在 $\Delta_I \geq 0$, 使对每轮 $t = 1, \dots, T$ 及任意 $a, b \in A(I)$ 都有

$$|v_i^{\sigma^{(t)}}(I, a) - v_i^{\sigma^{(t)}}(I, b)| \leq \Delta_I,$$

则遗憾匹配满足

$$R_{i,+}^T(I) \leq \Delta_I \sqrt{|A(I)|T}. \quad (19.20)$$

证明可用势函数 $\Phi_t = \sum_a [R_i^t(I, a)]_+^2$ 。每轮平方展开中的交叉项为

$$2 \sum_a [R_i^{t-1}(I, a)]_+ r_i^{(t)}(I, a).$$

当正遗憾和非零时, 式 (19.19) 使它正比于 $\sum_a \sigma_i^{(t)}(a | I) r_i^{(t)}(I, a) = 0$; 正遗憾和为零时, 交叉项也不为正。平方增量至多 $\sum_a (r_i^{(t)}(I, a))^2 \leq |A(I)| \Delta_I^2$ 。归纳得到 $\Phi_T \leq T |A(I)| \Delta_I^2$, 而每个正累计遗憾的平方不超过 Φ_T , 于是得到式 (19.20)。

19.4.4 一轮牌面更新的数值核对

用三张牌博弈核对一次参与者 2 的 CFR 更新。假设当前策略取

$$b_H = b_L = \frac{1}{2}, \quad \sigma_2(C | I_2) = \sigma_2(F | I_2) = \frac{1}{2}.$$

参与者 2 到达高牌质询节点和低牌质询节点的反事实权重都为

$$\frac{1}{2} \cdot \frac{1}{2} = \frac{1}{4}.$$

第一个因子来自机会发牌, 第二个因子来自参与者 1 质询。应对 C 时, 参与者 2 在高牌和低牌节点的收益分别为 -2 与 2, 所以

$$v_2(I_2, C) = \frac{1}{4}(-2) + \frac{1}{4}(2) = 0.$$

退让 F 时, 参与者 1 在两个节点都得到 1, 参与者 2 因而都得到 -1, 所以

$$v_2(I_2, F) = \frac{1}{4}(-1) + \frac{1}{4}(-1) = -\frac{1}{2}.$$

当前均匀策略的反事实价值为 -1/4, 本轮即时遗憾因此为

$$r_2(I_2, C) = \frac{1}{4}, \quad r_2(I_2, F) = -\frac{1}{4}.$$

若此前累计遗憾为零, 遗憾匹配在下一轮把全部概率放到 C。这个结果只描述一次局部更新; 参与者 2 更常应对以后, 低牌质询会变得不利, 参与者 1 的后续更新又会改变两个节点的权重。因而不能把首轮纯响应当成收敛策略, 也不能从这一个数值步骤推出均衡保证。

19.4.5 完全回忆把局部偏离分解为整局偏离

整局外部遗憾允许参与者把当前行为策略替换成任意固定行为策略:

$$R_i^T = \max_{\tilde{\sigma}_i} \sum_{t=1}^T \left[u_i(\tilde{\sigma}_i, \sigma_{-i}^{(t)}) - u_i(\sigma^{(t)}) \right]. \quad (19.21)$$

局部反事实遗憾之所以有用，在于它们能够上界这个看似覆盖整棵树的比较。

定理 19.10 CFR 的反事实遗憾分解 在有限完全回忆扩展式博弈中，

$$R_i^T \leq \sum_{I \in \mathcal{I}_i} R_{i,+}^T(I). \quad (19.22)$$

证明. 固定替代行为策略 $\tilde{\sigma}_i$. 证明先在一轮中把整局偏离逐层拆开，再对轮次求和。为看清拆分发生在哪里，对 $h \in I$ 定义当前策略在行动 a 后的条件续局收益

$$q_i^{(t)}(h, a) = \sum_{z \geq ha} \pi^{\sigma^{(t)}}(ha, z) u_i(z),$$

并以 $\tilde{q}_i^{(t)}(h, a)$ 表示对手和机会仍采用 $\sigma_{-i}^{(t)}$ ，而参与者 i 从 ha 以后采用 $\tilde{\sigma}_i$ 时的同一数值，即

$$\tilde{q}_i^{(t)}(h, a) = \sum_{z \geq ha} \pi^{(\tilde{\sigma}_i, \sigma_{-i}^{(t)})}(ha, z) u_i(z).$$

当前策略从 h 出发的续局收益为 $q_i^{(t)}(h) = \sum_b \sigma_i^{(t)}(b | I) q_i^{(t)}(h, b)$ 。在替代收益中加上再减去“只在当前行动改用替代分布、以后仍用当前策略”的收益，逐历史得到恒等式

$$\begin{aligned} & \sum_{a \in A(I)} \tilde{\sigma}_i(a | I) \tilde{q}_i^{(t)}(h, a) - q_i^{(t)}(h) \\ &= \sum_{a \in A(I)} \tilde{\sigma}_i(a | I) (q_i^{(t)}(h, a) - q_i^{(t)}(h)) \\ & \quad + \sum_{a \in A(I)} \tilde{\sigma}_i(a | I) (\tilde{q}_i^{(t)}(h, a) - q_i^{(t)}(h, a)). \end{aligned} \quad (19.23)$$

第一项只改变当前信息集的行动，第二项只记录当前行动之后继续偏离的收益。

下面把逐历史恒等式汇总到信息集。记 $\mathcal{C}_i(I, a)$ 为采取 a 以后、在参与者 i 再次行动时首次遇到的本人信息集集合；若在此之前终止，就没有后继信息集。令 $\tilde{v}_i^{(t)}(I)$ 为到达 I 的对手与机会权重仍取 $\pi_{-i}^{\sigma_{-i}^{(t)}}(h)$ ，但从 I 起参与者 i 都采用 $\tilde{\sigma}_i$ 的反事实价值，并记

$$D_i^{(t)}(I) = \tilde{v}_i^{(t)}(I) - v_i^{\sigma^{(t)}}(I), \quad L_i^{(t)}(I) = \sum_a \tilde{\sigma}_i(a | I) r_i^{(t)}(I, a).$$

将式 (19.23) 乘以 $\pi_{-i}^{\sigma_{-i}^{(t)}}(h)$ 并对 $h \in I$ 求和，得到信息集偏离收益恒等式

$$D_i^{(t)}(I) = L_i^{(t)}(I) + \sum_{a \in A(I)} \tilde{\sigma}_i(a | I) \sum_{I' \in \mathcal{C}_i(I, a)} D_i^{(t)}(I'). \quad (19.24)$$

这里没有漏掉从 I 到 I' 之间的概率：这段路径上参与者 i 不再行动，对手和机会的路径概率与 I 处已有的权重相乘，正好成为 I' 中各历史的 $\pi_{-i}^{\sigma_{-i}^{(t)}}$ 。在遇到下一个本人信息集以前终止的路径上，两种策略的后续行为相同，故其第二项为零。

完全回忆使本人信息集及边 $(I, a) \rightarrow I'$ 组成一个森林。确切地说，同一信息集 I' 中的所有历史具有相同的本人既往信息集与行动序列，所以每个非根信息集都有唯一的前驱边；对手或机会的多条历史可以汇入同一个 I' ，但这些历史只在 $\pi_{-i}^{\sigma_{-i}^{(t)}}$ 的求和中合并，不会把 I' 复制成多个后继。记 $\tilde{\pi}_i(I)$ 为替代策略沿该唯一本人前缀的行动概率乘积；根信息集的乘积约定为 1。这正是反事实价值中故意省去的自身到达概率。

现在按一个信息集之后还可能遇到的本人信息集层数归纳。最深信息集没有后继，式 (19.24) 给出 $D_i^{(t)}(I) = L_i^{(t)}(I)$ 。假设所有深度更小的后继子树都已展开，把它们代回同一恒等式；由于每个后继只有一个前驱，子树中的每个信息集恰好出现一次，其系数等于沿唯一前缀的 $\tilde{\sigma}_i$ 行动概率乘积。对森林的所有根求和后便得到

$$u_i(\tilde{\sigma}_i, \sigma_{-i}^{(t)}) - u_i(\sigma^{(t)}) = \sum_{I \in \mathcal{I}_i} \tilde{\pi}_i(I) \sum_{a \in A(I)} \tilde{\sigma}_i(a | I) r_i^{(t)}(I, a). \quad (19.25)$$

参与者 i 从未行动就终止的历史在两种策略下收益相同，因而不出现在右侧。式 (19.25) 明确分开了两类权重：对手与机会的权重已经包含在 $r_i^{(t)}(I, a)$ 中，自身在替代策略下到达 I 的权重则是外部系数 $\tilde{\pi}_i(I)$ 。

替代策略固定后， $\tilde{\pi}_i(I)$ 和 $\tilde{\sigma}_i(a | I)$ 都不随 t 变化。对式 (19.25) 求和，并使用 $0 \leq \tilde{\pi}_i(I) \leq 1$ ，可得

$$\begin{aligned} & \sum_{t=1}^T \left[u_i(\tilde{\sigma}_i, \sigma_{-i}^{(t)}) - u_i(\sigma^{(t)}) \right] \\ &= \sum_I \tilde{\pi}_i(I) \sum_a \tilde{\sigma}_i(a | I) R_i^T(I, a) \\ &\leq \sum_I \tilde{\pi}_i(I) \max_a R_i^T(I, a) \leq \sum_I R_{i,+}^T(I). \end{aligned}$$

最后一个不等式也覆盖 $\max_a R_i^T(I, a) < 0$ 的情形，因为此时相应正部为零。右侧与替代策略无关，再对 $\tilde{\sigma}_i$ 取最大，就得到式 (19.22)。 ■

若缺少完全回忆，同一当前信息集可能汇合不同的本人行动历史。此时局部策略无法知道应该补回哪条自身到达路径，上述递归可能重复计算或遗漏偏离收益，局部低遗憾便不再自动控制整局外部遗憾。

结合式 (19.20)，CFR 得到

$$R_i^T \leq \sum_{I \in \mathcal{I}_i} \Delta_I \sqrt{|A(I)|T}. \quad (19.26)$$

当信息集和行动数固定时，平均外部遗憾按 $O(T^{-1/2})$ 趋于零。

19.4.6 平均策略的权重与零和保证

行为策略不能在每个信息集直接做普通算术平均。某轮中一个信息集若几乎不会被参与者自己到达，该处局部概率不应与频繁到达轮次具有同样权重。完全回忆保证同一信息集 I 中的历史具有同一条本人行动前缀，因而 $\pi_i^{\sigma^{(t)}}(I)$ 定义为这条前缀上的本人行动概率乘积，与选取哪个 $h \in I$ 无关。记第 t 轮在本人序列 (I, a) 上的实现权重为

$$x_i^{(t)}(I, a) = \pi_i^{\sigma^{(t)}}(I) \sigma_i^{(t)}(a | I),$$

并令 $\bar{x}_i^T(I, a) = T^{-1} \sum_t x_i^{(t)}(I, a)$ 以及 $\bar{x}_i^T(I) = T^{-1} \sum_t \pi_i^{\sigma^{(t)}}(I)$ 。CFR 使用

$$\bar{\sigma}_i^T(a | I) = \frac{\sum_{t=1}^T \pi_i^{\sigma^{(t)}}(I) \sigma_i^{(t)}(a | I)}{\sum_{t=1}^T \pi_i^{\sigma^{(t)}}(I)}, \quad (19.27)$$

其中分母为零时可以任意指定。式 (19.27) 等价于

$$\bar{\sigma}_i^T(a | I) = \frac{\bar{x}_i^T(I, a)}{\bar{x}_i^T(I)}.$$

这个权重不是经验修正，而是实现计划平均所要求的条件概率。根本人序列的实现权重为 1。若 I 的唯一本人前驱序列终止于 (J, b) ，则每一轮都有 $\pi_i^{\sigma^{(t)}}(I) = x_i^{(t)}(J, b)$ ，对轮次平均后仍有 $\bar{x}_i^T(I) = \bar{x}_i^T(J, b)$ 。从根序列归纳，并在每个信息集应用上面的条件概率公式，得到

$$\pi_i^{\bar{\sigma}_i^T(I)} \bar{\sigma}_i^T(a | I) = \bar{x}_i^T(I, a) = \frac{1}{T} \sum_{t=1}^T x_i^{(t)}(I, a). \quad (19.28)$$

因此，加权平均行为策略实现的正是各轮本人实现计划的算术平均。分母为零意味着所有轮次到达该本人序列的概率都为零，此处怎样指定局部策略都不改变平均实现计划。

在两人零和博弈中，若双方平均外部遗憾分别不超过 $\varepsilon_1 T$ 与 $\varepsilon_2 T$ ，则平均策略满足

$$\max_{\sigma_1} u_1(\sigma_1, \bar{\sigma}_2^T) - \min_{\sigma_2} u_1(\bar{\sigma}_1^T, \sigma_2) \leq \varepsilon_1 + \varepsilon_2. \quad (19.29)$$

下面补出这个界。记第 t 轮第 1 位参与者的收益为 $u_1(\sigma_1^{(t)}, \sigma_2^{(t)})$ ，并令

$$\hat{u}_T = \frac{1}{T} \sum_{t=1}^T u_1(\sigma_1^{(t)}, \sigma_2^{(t)}).$$

终止历史 z 的概率可以写成机会概率与双方实现权重之积，所以期望收益

对双方实现计划分别线性。结合式 (19.28)，对任意固定策略 σ_1, σ_2 有

$$\begin{aligned} \frac{1}{T} \sum_{t=1}^T u_1(\sigma_1, \sigma_2^{(t)}) &= u_1(\sigma_1, \bar{\sigma}_2^T), \\ \frac{1}{T} \sum_{t=1}^T u_1(\sigma_1^{(t)}, \sigma_2) &= u_1(\bar{\sigma}_1^T, \sigma_2). \end{aligned} \quad (19.30)$$

第 1 位参与者的外部遗憾界除以 T ，再用第一条等式，得到

$$\max_{\sigma_1} u_1(\sigma_1, \bar{\sigma}_2^T) - \hat{u}_T \leq \varepsilon_1. \quad (19.31)$$

第 2 位参与者的收益为 $u_2 = -u_1$ 。把其外部遗憾界同样除以 T ，并用式 (19.30) 的第二条等式，得到

$$\hat{u}_T - \min_{\sigma_2} u_1(\bar{\sigma}_1^T, \sigma_2) \leq \varepsilon_2. \quad (19.32)$$

将式 (19.31) 与 (19.32) 相加，经验对局收益 $\hat{u}_T$ 消去，正好得到式 (19.29)。若博弈值为 v^* ，其左侧还可写成

$$\left[\max_{\sigma_1} u_1(\sigma_1, \bar{\sigma}_2^T) - v^* \right] + \left[v^* - \min_{\sigma_2} u_1(\bar{\sigma}_1^T, \sigma_2) \right].$$

两项分别衡量第 2 位和第 1 位参与者的平均策略可被最佳响应利用多少，且都非负；因此该和是双方平均策略的零和鞍点间隙。本章把这个和称为**联合可利用度**（joint exploitability）；若采用两项平均的口径，数值还需除以 2。间隙为零时，两者构成极小极大策略对。

式 (19.29) 保证的是两人零和博弈的平均策略，不是最后一次迭代。一般和博弈中，低外部遗憾使经验联合分布趋近 CCE，却不保证平均边缘策略构成 Nash 均衡。为看清这里保留的是哪种分布，令第 t 轮实际联合行动为 $\mathbf{a}^{(t)}$ ，经验分布为

$$\hat{\mu}_T(\mathbf{a}) = \frac{1}{T} \sum_{t=1}^T \mathbb{I}\{\mathbf{a}^{(t)} = \mathbf{a}\}.$$

若参与者 i 的平均外部收益遗憾至多 ε_i ，则对任意固定行动 a'_i ，

$$\mathbb{E}_{\mathbf{A} \sim \hat{\mu}_T} [u_i(\mathbf{A})] \geq \mathbb{E}_{\mathbf{A} \sim \hat{\mu}_T} [u_i(a'_i, \mathbf{A}_{-i})] - \varepsilon_i.$$

这正是带 ε_i 松弛的 CCE 不等式。若每个有向替换 $a_i \rightarrow b_i$ 的平均内部遗憾都不超过 ε_i ，则对任意映射 ϕ_i ，把发生 $A_i = a_i$ 的轮次按 a_i 分组并求和，可得 CE 偏离收益至多 $|A_i| \varepsilon_i$ ；若直接控制所有映射的交换遗憾，则松弛就是 ε_i 。这两个结论保留的是联合经验分布中的相关性，不能用各自经验边缘的乘积替代。

末次策略还可能持续循环。采样 CFR 若只访问部分历史，还要用第 9 章的无偏估计、方差和集中工具控制采样误差，不能把完整树上的确定性分解直接当作有限样本保证。

回到三张牌例子，参与者 2 的信息集使用高牌质询权重 $1/2$ 和低牌质询权重 $1/6$ 计算局部应对遗憾。若算法长期发现应对比退让更好，就提高 C 的概率；这一变化又会降低低牌质询的收益，使参与者 1 减少虚张声势。双方局部更新相互改变下一轮价值，CFR 保证累计偏离受控，却不要求这两个概率逐轮单调走向 $1/3$ 。

19.5 信用分配与多方收益

19.5.1 合作分配先要定义联盟能够取得什么

前四节把参与者的收益函数视为已给定对象。合作问题进一步询问：若若干参与者共享信息、模型或资源并产生共同收益，这个收益应怎样分配？本节所说的**多方信用分配**（multi-party credit allocation），是根据各个联盟能够取得的价值，为每位参与者确定贡献份额 $\psi_i(v)$ 。若还要求预算平衡，则这些份额满足 $\sum_i \psi_i(v) = v(N)$ 。它分配的是参与者对联盟价值的贡献，不是把一条轨迹的延迟奖励传回各时间步；后者将在强化学习部分作为时序信用分配问题讨论。

可转移效用合作博弈（transferable-utility cooperative game）由参与者集合 N 和联盟价值函数

$$v : 2^N \rightarrow \mathbb{R}, \quad v(\emptyset) = 0$$

组成。 $v(S)$ 表示联盟 S 独立合作时可取得并能在成员之间转移的总收益。

联盟价值不是从单个模型输出自动得到的。对牌面判断任务，可以把 $v(S)$ 定义为联盟 S 共享信号后，相对于无信号基线减少的最优期望损失；也可以定义为收入、正确判断数或节省的核验成本。不同定义会产生不同分配。若参与者的收益不能用同一尺度转移，例如一方关心隐私、另一方关心延迟，就需要非可转移效用模型，不能先相加再假装总量可任意拆分。

参与者 i 加入已有联盟 $S \subseteq N \setminus \{i\}$ 的边际贡献为

$$v(S \cup \{i\}) - v(S).$$

它依赖先到者集合 S 。两位牌面观察者可能各自只能提供模糊线索，合在一起却能确定牌面；此时任何一人的“独立贡献”都不能由单独使用他的信号一次决定。

19.5.2 Shapley 值平均所有加入次序

Shapley 值 (Shapley value) 把参与者在所有随机加入次序中的边际贡献取平均⁵。对 $n = |N|$, 参与者 i 的分配为

$$\phi_i(v) = \sum_{S \subseteq N \setminus \{i\}} \frac{|S|!(n - |S| - 1)!}{n!} [v(S \cup \{i\}) - v(S)]. \quad (19.33)$$

系数是随机排列中恰好由 S 排在 i 之前的概率: S 内部有 $|S|!$ 种次序, 其余参与者在 i 之后有 $(n - |S| - 1)!$ 种次序, 总排列数为 $n!$ 。

Shapley 值满足四项要求。若两位参与者对所有不含二者的联盟产生相同边际贡献, **对称性**要求二者分配相同; 若参与者对任意联盟的边际贡献都为零, **虚设参与者性质**要求其分配为零; **有效性**要求 $\sum_i \phi_i(v) = v(N)$; **可加性**要求对两个价值函数 v, w , 有 $\phi_i(v + w) = \phi_i(v) + \phi_i(w)$ 。

定理 19.11 Shapley 值的公理刻画 在有限可转移效用合作博弈上, 同时满足对称性、虚设参与者性质、有效性和可加性的分配规则唯一, 并由式 (19.33) 给出。

证明. 先验证式 (19.33) 满足四项性质。它是随机排列下边际贡献的期望。每个排列中, 所有参与者的边际贡献沿加入次序望远镜相加为

$$v(N) - v(\emptyset) = v(N),$$

取期望得到有效性。交换两位对称参与者不会改变排列分布或边际贡献分布, 得到对称性。虚设参与者的每项边际贡献都为零。边际贡献关于价值函数线性, 取期望后得到可加性。

再证唯一性。设 Φ 是任意满足四项公理的分配规则。对每个非空集合 $T \subseteq N$, 定义一致联盟博弈

$$u_T(S) = \begin{cases} 1, & T \subseteq S, \\ 0, & T \not\subseteq S. \end{cases}$$

任意满足 $v(\emptyset) = 0$ 的价值函数都能唯一写成

$$v = \sum_{\emptyset \neq T \subseteq N} c_T u_T, \quad c_T = \sum_{R \subseteq T} (-1)^{|T| - |R|} v(R), \quad (19.34)$$

这是子集格上的包含-排除展开。

还要处理展开式中的任意实系数, 不能只由重复相加得到整数或有理数倍。对任意 $c \in \mathbb{R}$, 在博弈 $c u_T$ 中, T 外的参与者都是虚设参与者, 分配必须为零; T 内参与者彼此对称, 有效性又要求他们的分配和为 c , 所

⁵ L. S. Shapley, “A Value for n -Person Games”, in: *Contributions to the Theory of Games II*, ed. by H. W. Kuhn, A. W. Tucker, vol. 28, Annals of Mathematics Studies, Princeton University Press, 1953, pp. 307–318

以每人只能得到 $c/|T|$ 。这个结论直接覆盖正、负及无理的 c ，没有预先假设分配规则连续。

式 (19.34) 只有有限项。可加性因此给出

$$\Phi(v) = \sum_{\emptyset \neq T \subseteq N} \Phi(c_T u_T),$$

而每一项已经由上一段唯一确定，故任意 v 上的分配也唯一。特别地，对任意 $\alpha \in \mathbb{R}$ ，对 αv 使用同一展开便得到 $\Phi(\alpha v) = \alpha \Phi(v)$ ，这补出了实齐次性。前半部分已经证明式 (19.33) 满足这些公理，故它就是唯一规则。 ■

19.5.3 三个信息提供者的可复核分配

把牌面任务扩展为三位信息提供者。参与者 1 观察牌背纹理，参与者 2 观察发牌动作，参与者 3 提供一次较弱的设备校验。以“相对于无信息基线减少的期望损失”为统一收益单位，假设教学构造的联盟价值为

S	$\emptyset$	$\{1\}$	$\{2\}$	$\{3\}$	$\{1, 2\}$	$\{1, 3\}$	$\{2, 3\}$	$\{1, 2, 3\}$
$v(S)$	0	1	1	0	3	2	2	4

这些数值只用于展示互补贡献：前两位各自有用，二者合并额外增益较大；第三位单独无用，却能校验已有线索。

对参与者 1，四类前驱联盟的贡献给出

$$\begin{aligned} \phi_1(v) &= \frac{1}{3}(1 - 0) + \frac{1}{6}(3 - 1) + \frac{1}{6}(2 - 0) + \frac{1}{3}(4 - 2) \\ &= \frac{5}{3}. \end{aligned}$$

对称性给出 $\phi_2(v) = 5/3$ 。参与者 3 的分配为

$$\begin{aligned} \phi_3(v) &= \frac{1}{3}(0 - 0) + \frac{1}{6}(2 - 1) + \frac{1}{6}(2 - 1) + \frac{1}{3}(4 - 3) \\ &= \frac{2}{3}. \end{aligned}$$

三者之和为 $4 = v(N)$ ，与有效性一致。参与者 3 虽然单独价值为零，却不是虚设参与者，因为加入 $\{1\}$ 、 $\{2\}$ 或 $\{1, 2\}$ 都会增加联盟价值。只按单人表现分配会漏掉这种互补性。

若把价值改成模型预测分数，Shapley 公式仍可计算，但解释也随之改变。它分配的是所定义价值函数相对于基线的差，不自动等于真实因果贡献。特征彼此相关时，“缺少某个特征”的联盟输入怎样构造还需要条件分布、边缘分布或干预语义；这些选择分别回答预测归因与因果效应问题，不能只用同一个 Shapley 名称消除差异。

19.5.4 稳定性、公平性与多目标收益是不同要求

一个有效分配仍可能被某个联盟拒绝。若分配向量为 $\mathbf{x}$ ，并满足

$$\sum_{i \in N} x_i = v(N),$$

但存在联盟 S 使

$$\sum_{i \in S} x_i < v(S),$$

那么该联盟单独合作可取得更多总收益。要求所有联盟都没有这种阻挡，并保持总收益完全分配，得到合作博弈的**核心** (core)。Shapley 值不一定属于核心，核心也可能为空。前者由边际贡献平均和四项公理定义，后者由联盟偏离稳定性定义。

当收益不能转移时，应直接保留收益向量 $\mathbf{u}(\mathbf{a}) = (u_1(\mathbf{a}), \dots, u_n(\mathbf{a}))$ 。若不存在另一可行方案使所有参与者收益都不下降且至少一人严格上升，当前方案称为 **Pareto 最优** (Pareto optimal)。Pareto 最优只排除共同改进，通常形成一整个前沿，并不选择其中哪一点。第 3.12 节中的共同下降方向是一阶局部判据，也不能单独决定全局分配。

给定分歧点 $\mathbf{d}$ 和可行收益集合 $U \subseteq \mathbb{R}^n$ ，**Nash 协商解** (Nash bargaining solution) 在参与者都不低于分歧收益的区域中选择

$$\max_{\mathbf{u} \in U, \mathbf{u} \geq \mathbf{d}} \prod_{i=1}^n (u_i - d_i), \quad (19.35)$$

其中向量不等式逐坐标理解。分歧点表示谈判失败时每人的收益，因而乘积比较的是相对于退出结果的增益，而不是原始收益本身。

定理 19.12 Nash 乘积的存在、唯一性与 Pareto 性质 设 U 非空、紧且凸，并存在 $\hat{\mathbf{u}} \in U$ 满足 $\hat{\mathbf{u}} > \mathbf{d}$ 。则式 (19.35) 存在唯一的最优收益向量 $\mathbf{u}^* > \mathbf{d}$ ，且 $\mathbf{u}^*$ 是 Pareto 最优的。若每位参与者的效用与分歧收益同时作正仿射变换 $u'_i = a_i u_i + b_i$ 、 $d'_i = a_i d_i + b_i$ ，其中 $a_i > 0$ ，变换后的解正是 $\mathbf{u}^{*'} = (a_i u_i^* + b_i)_{i=1}^n$ 。

证明. 个体可接受集合

$$K = U \cap \{\mathbf{u} : \mathbf{u} \geq \mathbf{d}\}$$

非空且紧，乘积目标连续，所以最大值能够达到。严格可行点 $\hat{\mathbf{u}}$ 的乘积为正，而任何至少一个坐标等于相应 d_i 的点乘积为零，因此任一最优解都严

格满足 $\mathbf{u} > \mathbf{d}$ 。在这个正增益区域，最大化乘积等价于最大化

$$F(\mathbf{u}) = \sum_{i=1}^n \log(u_i - d_i).$$

每个对数项在其坐标上严格凹，故 F 在正增益区域严格凹。若有两个不同最优点，凸性保证它们的中点仍在 U 内，严格凹性却使中点目标严格大于两端，产生矛盾。因此最优收益向量唯一。

若存在 $\tilde{\mathbf{u}} \in U$ 使 $\tilde{\mathbf{u}} \geq \mathbf{u}^*$ 且至少一个坐标严格更大，则所有增益保持为正，乘积严格增加，与最优性矛盾，所以 $\mathbf{u}^*$ 是 Pareto 最优的。正仿射变换后，每个增益变为 $u'_i - d'_i = a_i(u_i - d_i)$ ，整个乘积只乘上与候选点无关的正常数 $\prod_i a_i$ 。可行收益集合与最优点按同一坐标变换对应，因而最优选择不变。 ■

例如，两位参与者的可行收益满足

$$U = \{(u_1, u_2) : u_1 \geq 0, u_2 \geq 0, u_1 + u_2 \leq 6\}, \quad \mathbf{d} = (1, 1).$$

任何最优点都在边界 $u_1 + u_2 = 6$ 上，否则还能同时增加收益。令 $x = u_1 - 1$ ，则 $u_2 - 1 = 4 - x$ ，Nash 乘积为

$$x(4 - x) = 4 - (x - 2)^2,$$

故唯一解为 $(u_1^*, u_2^*) = (3, 3)$ 。若只把分歧点改为 $(0, 1)$ ，边界上的乘积变为 $u_1(5 - u_1)$ ，解随之变成 $(5/2, 7/2)$ 。这个算例说明，协商解的“公平”相对于明确的退出收益而言，并不是脱离分歧点的绝对均分。

没有共同严格正增益时，对数证明不适用，乘积还可能在多个零增益点同时达到最大；若 U 非凸，严格凹性也不能排除不同连通部分上的多个最优点。改变分歧点会改变解，收益若作一般非线性变换，乘积比较同样会改变。这个“协商解”与非合作博弈中的“Nash 均衡”共享提出者姓名，却解决不同问题。

牌面任务由此可以得到三种互不替代的判断。若参与者对抗，极小极大或 Nash 均衡检查单方策略响应；若各方重复学习，遗憾检查相对于某个偏离类的长期损失；若各方合作，Shapley 值、核心或协商解分别按边际贡献、联盟稳定性或分歧点增益分配收益。实际多方系统还可能同时具有合作与竞争关系，此时必须先写清收益、协调和退出条件，再选择相应解概念。

19.6 本章小结

当其他参与者也会选择策略时，行动后果由联合策略决定。有限零和博弈把双方保证值写成一队线性规划：行方保证收益下界，列方限制收益上界，强对偶使两种证书在同一个博弈值处相遇。三张牌例子以双方的随机化取得博弈值 $2/3$ ，纯策略不能取得这一相互防御。一般和博弈没有共同博弈值，Nash 均衡改为逐人排除单方有利偏离。有限混合策略空间是紧凸单纯形，Sperner 引理与 Brouwer 定理建立连续不动点，连续近似选择、紧性与闭图再给出 Kakutani 路线下的 Nash 存在性，但不提供唯一性、求解效率或迭代收敛。相关均衡与粗相关均衡还通过偏离发生在看到建议之前还是之后来区分允许的偏离。扩展式博弈把行动次序、私人观察和不可区分历史写入信息集。行为策略在每个信息集局部随机化，Kuhn 实现等价说明完全回忆何时使局部表示与完整计划相容。反事实价值去掉自身到达权重，使少被当前策略访问的信息集仍能比较行动；这种加权不是因果模型中固定外生背景后的反事实。重复博弈中的低遗憾是相对于明确比较类的累计保证。投影次梯度由距离平方递推得到 $O(\sqrt{T})$ 外部遗憾；CFR 在每个信息集控制即时反事实遗憾。完全回忆使整局偏离沿本人信息集树分解，由局部正遗憾之和上界全局外部遗憾。两人零和时，加权平均策略趋近极小极大解；一般和、采样版本和末次迭代需要分别分析。合作问题改变了待回答的对象。Shapley 值在联盟价值已经定义后，平均所有加入次序中的边际贡献，并由对称性、虚设参与者、有效性和可加性唯一刻画。它不自动保证联盟稳定，也不把预测归因升级为因果贡献。核心检查联盟是否愿意退出，Pareto 条件排除共同改善；Nash 乘积在紧凸且存在共同严格增益时选出唯一收益向量，解仍依赖分歧点。多方决策的结论须注明收益结构、可用信息、允许偏离和时间口径；只说“达到均衡”或“分配公平”，不足以确定究竟获得了哪一种保证。第 20 章将把前述数学工具按后续研究问题重新组织，明确不同保证进入学习、推断、迁移与部署时各自控制什么对象。

数学基础与后续研究

前述各章分别研究了函数与极限、空间与变换、随机性与证据、离散结构，以及随时间演化的状态与行动。把这些内容逐章学会之后，还会留下一个实际问题：面对机器学习中的某个研究命题，应当从哪一种数学对象开始，又怎样判断一个熟悉的定理能否用于当前设定？

困难不在于记住更多公式，而在于辨认公式所控制的对象。同一个投影既可以描述最小二乘拟合，也可以描述条件期望；同一个谱既可以揭示数据的低秩方向，也可以刻画动态系统的衰减模式。公式相似并不表示结论相同。目标函数、观测制度、候选空间和数据生成过程只要改变一项，原有推导中的条件就可能需要重新核对。

本章按后续研究方向组织这些联系。每节都从一个可手算的小问题出发，指出前文数学进入推导的位置，并把已经得到的保证与尚待研究章节定义的对象分开。这里不重复前述各章的完整证明，也不提前展开具体模型的全部训练流程。读者需要形成的是一种工作方式：先写清研究问题的对象与量词，再找到可复用的数学接口，最后检查接口条件是否真的由任务、数据和算法满足。

20.1 学习理论与泛化

20.1.1 从候选选择到总体风险

学习理论要回答的不是“训练误差能否算出”，而是“用训练数据选出的函数在新样本上会怎样”。选择动作使问题发生了变化：对一个事先固定的函数成立的概率界，未必能直接用于看过同一批数据后才选出的函数。第 8 章建立的同时误差控制，正是从单个随机平均走向数据依赖选择的入口。

设有限候选类为 $\mathcal{H} = \{h_1, \dots, h_M\}$ ，样本 $Z_1, \dots, Z_n$ 独立同分布，损失 $\ell(h, Z) \in [0, 1]$ 。记总体风险、经验风险、经验最优解和类内总体最优解分

别为

$$\begin{aligned} R(h) &= \mathbb{E}[\ell(h, Z)], \\ \hat{R}_n(h) &= \frac{1}{n} \sum_{i=1}^n \ell(h, Z_i), \\ \hat{h} &\in \arg \min_{h \in \mathcal{H}} \hat{R}_n(h), \\ h^* &\in \arg \min_{h \in \mathcal{H}} R(h). \end{aligned}$$

经验最优解依赖全部样本，不能在选择完成后把它当作预先固定的候选。

定理 8.14 已经从 Hoeffding 不等式和联合界证明：以至少 $1 - \delta$ 的概率，全部 $h \in \mathcal{H}$ 同时满足

$$|R(h) - \hat{R}_n(h)| \leq \varepsilon_n(\delta) = \sqrt{\frac{\log(2M/\delta)}{2n}}.$$

在这个同时事件上，把 $\hat{h}$ 从总体风险换到经验风险，使用经验最优性与 h^* 比较，再换回总体风险，便得到

$$R(\hat{h}) \leq R(h^*) + 2\varepsilon_n(\delta). \quad (20.1)$$

这里不重复第 8 章的一般证明；关键接口是误差事件必须同时覆盖数据选出的 $\hat{h}$ 与用于比较的 h^* 。

实际求解器未必返回精确经验最优解。若 $\tilde{h} \in \mathcal{H}$ 只保证

$$\hat{R}_n(\tilde{h}) \leq \inf_{h \in \mathcal{H}} \hat{R}_n(h) + \eta,$$

则沿同一条比较路径可得

$$R(\tilde{h}) \leq R(h^*) + 2\varepsilon_n(\delta) + \eta.$$

这里的 η 来自优化过程， $\varepsilon_n(\delta)$ 来自有限样本；两项能够进入同一个上界，不表示它们可由同一种论证减小。

示例 20.1 有限候选中的选择代价 假设 $M = 8$ 、 $n = 200$ ，并取 $\delta = 0.05$ 。代入上式可得

$$\varepsilon_n(\delta) = \sqrt{\frac{\log 320}{400}} \approx 0.120.$$

因而这个简单界只保证 $R(\hat{h}) \leq R(h^*) + 0.240$ 。若把 M 误写成 1，便会忽略从八个候选中选择所付出的同时控制代价。数值较松不表示推导无效；它提示后续研究要利用函数类结构，不能只看候选数。

这个风险差还不是全部学习误差。若真实最优预测规则不在 $\mathcal{H}$ 中, $R(h^*)$ 与所有可测规则中的最优风险之间存在**逼近误差**；有限样本使经验量偏离总体量，产生**估计误差**；训练算法若只返回近似经验最优解，还会产生**求解误差**。第4章用函数空间、覆盖和组合复杂度描述前两项之间的结构关系，第3章则分析后一项。三个来源可以相加进入一个上界，却不能因为都叫“误差”而由同一个定理控制。

20.1.2 从有限候选到函数类和算法

当 $\mathcal{H}$ 无限时，有限并集界不再直接适用。覆盖数、增长函数和 Rademacher 型复杂度通过“在样本分辨率下实际有多少种行为”替代 M ；算法稳定性改为比较替换一个样本前后的输出；信息论方法则控制算法输出携带了多少关于训练样本的信息。这些是不同证明路径，不要求同时成立。用有限覆盖代替原函数类时，覆盖所用的度量还必须能够控制当前损失差；参数空间中的欧氏距离小，本身不保证预测损失也接近。

示例 20.2 有限选择器的两类控制 继续使用例 20.1 中的 $M = 8, n = 200$ ，先把训练算法 A 视为确定性算法，并把输出记为 $W = A(S) \in \mathcal{H}$ 。若对任意只相差一个样本的 S, S' 和任意测试点 z ，都有

$$|\ell(A(S), z) - \ell(A(S'), z)| \leq \beta,$$

就可用留一替换把稳定性系数接到期望泛化差。具体地，令 Z'_i 是 Z_i 的独立同分布副本，并以 $S^{(i)}$ 表示把 S 中的 Z_i 替换为 Z'_i 所得的数据集。交换 Z_i 与 Z'_i 不改变联合分布，因此

$$\begin{aligned} & |\mathbb{E}[R(A(S)) - \hat{R}_n(A(S))]| \\ &= \left| \frac{1}{n} \sum_{i=1}^n \mathbb{E}[\ell(A(S^{(i)}), Z_i) - \ell(A(S), Z_i)] \right| \leq \beta. \end{aligned}$$

第3章的稳定性路线可以提供这里所需的稳定系数，上述替换论证则说明该系数为何控制期望泛化差。若 A 含内部随机性，可以固定同一个随机种子耦合两次运行并要求上述界对种子成立，或改用对算法随机性取期望的稳定性定义；不能省略这一随机性约定。这里真正需要核对的是算法对换样本是否敏感。未经正则化的经验风险最小化可能在两个经验风险几乎相同的候选之间切换；若它们在某个 z 上的损失分别为 0 和 1，那么一次换样本就可能使上式只能取 $\beta = 1$ 。候选只有八个并不自动带来小稳定性。

信息控制考察同一输出 W 携带了多少训练样本信息。因为 W 至

多取八个值,

$$I(W;S) \leq H(W) \leq \log 8.$$

对 $[0,1]$ 值损失, 第 11 章的换测度界因而给出

$$|\mathbb{E}[R(W) - \hat{R}_n(W)]| \leq \sqrt{\frac{I(W;S)}{2n}} \leq \sqrt{\frac{\log 8}{400}} \approx 0.072.$$

这个数利用了输出范围有限, 却没有证明换一个样本时输出接近。它控制的是期望泛化差, 也不同于例 20.1 中以高概率成立的超额风险界。稳定性与互信息可以分析同一个选择器, 但条件和结论不能互换。

20.1.3 从误差上界到学习与计算的边界

信息论下界进一步说明任何方法需要多少观测¹。而第 13 章中的计算复杂度讨论给定输入后能否在可接受资源内求出结果。样本不足与计算困难是两种限制: 前者即使给算法无限计算时间也可能无法消除, 后者则可能发生在统计信息已经足够时。

式 (20.1) 的边界很明确: 损失有界、样本独立同分布、候选类在看见样本前固定, 而且使用同一分布定义经验风险和总体风险。数据依赖地构造候选类、反复查看验证结果、面对相关序列或发生分布迁移时, 都要改用相应的条件化、序贯控制或换测度工具。后续机器学习理论章节将在二分类、多分类、深层函数类和迁移设定中分别定义可学习对象; 本节的推导只提供辨认“表示、样本、算法与计算”四类问题的起点。

¹ T. M. Cover, J. A. Thomas, *Elements of Information Theory*, Wiley, 2006, 2nd ed.

20.2 经典模型、核方法与几何表示

20.2.1 从拟合目标到投影、谱与正则化

经典模型经常共享平方损失、距离或谱分解, 但共享运算不表示共享研究目标。回归关心预测量与响应之间的误差, 降维关心表示保留了什么结构, 聚类则需要规定何种群组关系才算成功。先看一个近共线回归例子, 可以同时辨认拟合、敏感性与正则化分别由哪一部分数学控制。

令设计矩阵与响应为

$$\mathbf{X} = \begin{bmatrix} 1 & 1 \\ 1 & 1 + \epsilon \end{bmatrix}, \quad \mathbf{y} = \begin{bmatrix} 1 \\ 1 \end{bmatrix},$$

其中 ϵ 很小。两列特征几乎相同, 因此某些系数组合对预测的作用也几乎

相同。无正则最小二乘解满足正规方程

$$\mathbf{X}^\top \mathbf{X} \hat{\mathbf{w}} = \mathbf{X}^\top \mathbf{y}.$$

矩阵 $\mathbf{X}^\top \mathbf{X}$ 的行列式为 ε^2 ，当 $\varepsilon \rightarrow 0$ 时趋近奇异。第 5 章的投影说明 $\mathbf{X} \hat{\mathbf{w}}$ 是 $\mathbf{y}$ 在列空间上的投影，第 6 章的奇异值与条件数则说明系数为何对微小扰动敏感。

加入岭正则项后，目标变为

$$\min_{\mathbf{w} \in \mathbb{R}^2} \frac{1}{2} \|\mathbf{X} \mathbf{w} - \mathbf{y}\|_2^2 + \frac{\lambda}{2} \|\mathbf{w}\|_2^2, \quad \lambda > 0,$$

其唯一解为

$$\hat{\mathbf{w}}_\lambda = (\mathbf{X}^\top \mathbf{X} + \lambda \mathbf{I})^{-1} \mathbf{X}^\top \mathbf{y}. \quad (20.2)$$

若 σ_j 是 $\mathbf{X}$ 的奇异值，那么相应谱方向上的逆因子从 $1/\sigma_j^2$ 变为 $1/(\sigma_j^2 + \lambda)$ 。正则化抑制了小奇异值方向的放大，但也改变了拟合目标。它改善的是代数条件与系数稳定性，不自动证明新样本上的总体风险更小。

示例 20.3 共线特征的可辨方向 取 $\varepsilon = 0$ 时，两列完全相同，所有满足 $w_1 + w_2 = 1$ 的向量都给出 $\mathbf{X} \mathbf{w} = \mathbf{y}$ ，所以预测值唯一而系数不唯一。加入 $\lambda > 0$ 后，严格凸性保证岭目标有唯一解，对称性使该解满足 $w_1 = w_2$ ，于是

$$\hat{w}_{\lambda,1} = \hat{w}_{\lambda,2} = \frac{2}{4 + \lambda}.$$

此时

$$\mathbf{X} \hat{\mathbf{w}}_\lambda = \frac{4}{4 + \lambda} \mathbf{y},$$

所以有限 λ 下的岭解不是零残差解，而是以收缩偏差换取较稳定的系数。零残差解集合中的最小范数解是 $(1/2, 1/2)^\top$ ；只有当 $\lambda \downarrow 0$ 时，岭解才趋于这个代表。这个结论仍不能说明两个特征具有相同的现实含义。

20.2.2 从有限特征到核空间中的计算

同一个拟合思想可以从有限维系数扩展到函数空间。设 $\mathcal{H}_K$ 是核 K 对应的再生核 Hilbert 空间，考虑

$$\min_{f \in \mathcal{H}_K} \sum_{i=1}^n (f(\mathbf{x}_i) - y_i)^2 + \lambda \|f\|_{\mathcal{H}_K}^2.$$

把任意 f 正交分解为

$$f = f_{\parallel} + f_{\perp}, \quad f_{\parallel} \in \text{span}\{K(\mathbf{x}_1, \cdot), \dots, K(\mathbf{x}_n, \cdot)\}.$$

再生性质给出

$$f_{\perp}(\mathbf{x}_i) = \langle f_{\perp}, K(\mathbf{x}_i, \cdot) \rangle_{\mathcal{H}_K} = 0.$$

因此 f 与 $f_{\parallel}$ 在训练点上的损失相同，而

$$\|f\|_{\mathcal{H}_K}^2 = \|f_{\parallel}\|_{\mathcal{H}_K}^2 + \|f_{\perp}\|_{\mathcal{H}_K}^2 \geq \|f_{\parallel}\|_{\mathcal{H}_K}^2.$$

任何最优解都可取成

$$f^*(\cdot) = \sum_{i=1}^n \alpha_i K(\mathbf{x}_i, \cdot). \quad (20.3)$$

这段投影推导解释了为什么无限维候选仍能化为 n 个系数，而不是声称无限维问题本身已经消失。核矩阵的条件数、正则项和求解器仍决定数值计算是否可靠。

改变核会改变哪些函数被视为平滑或相近，改变正则项则改变同一函数空间中的偏好。这两种改变分别作用于表示和选择准则。第 7 章把距离推广到局部度量、流形与对称结构，第 14 章把邻域关系写成图并用图谱分析变化模式。它们可用于组织降维或聚类，却不能仅凭“距离保留”推出类别、语义或因果关系也被保留。

20.2.3 从预测输出到群组与低维关系

同一数据矩阵也可以作为无监督分析的对象，但这时目标已经改变。为使误差可以逐项复核，在上例取 $\varepsilon = 1$ ，于是

$$\mathbf{X} = \begin{bmatrix} 1 & 1 \\ 1 & 2 \end{bmatrix}, \quad \mathbf{X}^T \mathbf{X} = \begin{bmatrix} 2 & 3 \\ 3 & 5 \end{bmatrix}.$$

$\mathbf{X}^T \mathbf{X}$ 的两个特征值为

$$\sigma_1^2 = \frac{7 + 3\sqrt{5}}{2}, \quad \sigma_2^2 = \frac{7 - 3\sqrt{5}}{2}.$$

若截断 SVD 只保留第一项 $\mathbf{X}_1 = \sigma_1 \mathbf{u}_1 \mathbf{v}_1^T$ ，定理 6.4 给出

$$\|\mathbf{X} - \mathbf{X}_1\|_F^2 = \sigma_2^2 = \frac{7 - 3\sqrt{5}}{2} \approx 0.146. \quad (20.4)$$

这个数是数据矩阵的秩一重构误差，不是回归误差。回归仍使用同一未中心化矩阵 $\mathbf{X}$ 和 $\mathbf{y} = (1, 1)^T$ ，并最小化 $\|\mathbf{X}\mathbf{w} - \mathbf{y}\|_2^2$ ；此时 $\mathbf{w} = (1, 0)^T$ 使误差为零。若把两行 $(1, 1)$ 与 $(1, 2)$ 视为样本做不预先中心化的一维降维，式 (20.4) 衡量的是到所选秩一线性表示的平方重构误差。若改做单簇聚类，目

标又变为到质心 $\mathbf{m} = (1, 3/2)^\top$ 的簇内平方和，其值为

$$\|(1, 1)^\top - \mathbf{m}\|_2^2 + \|(1, 2)^\top - \mathbf{m}\|_2^2 = \frac{1}{2}.$$

输入数据没有改变，但监督响应、低秩表示与离散分组三种输出接口不同，因而三个数不能互相充当成功标准。

本节例子的结论止于给定样本、给定核与给定正则参数下的表示和求解。噪声模型、预测区间、超参数选择及总体风险需要统计假设；聚类和降维还须另行定义群组或结构保真的评价目标。后续经典模型部分会补上输出语义、数据机制与评价协议。投影、谱和核是可复用工具，不是这些任务共同的成功标准。

20.3 神经网络的结构与表示

20.3.1 从共享局部运算到卷积与等变性

神经网络的结构研究关心怎样把输入中的先验关系写进函数族。空间平移、节点重编号和时间推进都可表现为“变换输入后，输出应按可预测方式变化”，但三者作用的对象不同。一个短序列上的共享局部算子可以把张量运算、卷积、群作用和边界条件连接起来。

考虑长度为 4 的循环序列

$$\mathbf{x} = [x_0 \quad x_1 \quad x_2 \quad x_3]^\top$$

以及长度为 2 的核 $\mathbf{k} = [k_0, k_1]^\top$ 。定义循环卷积算子

$$(T_{\mathbf{k}}\mathbf{x})_i = k_0x_i + k_1x_{(i-1) \bmod 4}.$$

令 S 为循环右移一格的置换矩阵，即 $(S\mathbf{x})_i = x_{(i-1) \bmod 4}$ 。直接代入可得

$$\begin{aligned} (T_{\mathbf{k}}S\mathbf{x})_i &= k_0x_{(i-1) \bmod 4} + k_1x_{(i-2) \bmod 4} \\ &= (ST_{\mathbf{k}}\mathbf{x})_i. \end{aligned} \tag{20.5}$$

所以 $T_{\mathbf{k}}S = ST_{\mathbf{k}}$ 。输入平移后，输出发生同样平移，这就是该算子对循环平移的**等变性**：它不要求输出保持不变，而要求输出按规定的群作用同步变化。

示例 20.4 边界条件改变结构关系 取 $\mathbf{x} = [1, 2, 0, 0]^\top$ 、 $\mathbf{k} = [1, -1]^\top$ ，则

$$T_{\mathbf{k}}\mathbf{x} = [1, 1, -2, 0]^\top.$$

循环右移输入得到 $[0, 1, 2, 0]^\top$ ，再卷积得到 $[0, 1, 1, -2]^\top$ ，恰好是原输出的循环右移。若把循环边界改成左端补零，首尾不再属于同一平移轨道，上述交换关系在边界处失效。共享参数本身不足以保证任意边界处理下的精确等变。

第 15 章还说明，循环卷积在离散傅里叶坐标中化为逐频率乘法。这同时给出表示和计算两种认识：每个频率模式被核的频率响应独立缩放，而快速变换可以减少某些卷积的运算量。采样或池化随后会改变可分辨频率；没有抗混叠条件时，低采样率中的低频模式可能来自原信号的多个高频成分。结构约束限制了函数族，快速算法组织了计算，采样条件决定信息保留，三者不能合并成一句“卷积保留结构”。

20.3.2 从规则序列到图和状态表示

输入若由无规则关系构成，变换不再是循环平移，而是节点重编号。图上的映射 Φ 若满足

$$\Phi(PX, PAP^\top) = P\Phi(X, A)$$

对允许的置换矩阵 P 成立，才具有相应的置换等变性。第 14 章提供邻接、路径、分离与图谱对象，第 7 章提供群作用下不变与等变的统一语言。这条等式只说明重编号一致性，不说明映射能够区分所有不同图结构。

持续到达的序列又引入状态。若

$$\mathbf{s}_{t+1} = \mathbf{A}\mathbf{s}_t + \mathbf{B}\mathbf{x}_t,$$

展开后可得

$$\mathbf{s}_t = \mathbf{A}^t \mathbf{s}_0 + \sum_{j=0}^{t-1} \mathbf{A}^{t-1-j} \mathbf{B} \mathbf{x}_j.$$

第 16 章的谱与 Lyapunov 工具判断历史扰动如何衰减或放大。这个状态核与卷积形式相似，但当 $\mathbf{A}$ 随输入或时间改变时，固定卷积核不再描述完整递推。

20.3.3 从复合映射到敏感性与逼近能力

结构确定后，还要判断复合映射对输入扰动的局部响应。对

$$\mathbf{h} = f(\mathbf{x}), \quad \mathbf{y} = g(\mathbf{h}),$$

链式法则给出

$$\mathbf{J}_{g \circ f}(\mathbf{x}) = \mathbf{J}_g(\mathbf{h}) \mathbf{J}_f(\mathbf{x}),$$

进而有局部范数界

$$\|\mathbf{J}_{g \circ f}(\mathbf{x})\|_2 \leq \|\mathbf{J}_g(\mathbf{h})\|_2 \|\mathbf{J}_f(\mathbf{x})\|_2.$$

它控制局部敏感性，却不等价于第 4 章讨论的逼近能力。一个函数族可能足以逼近目标，但具体参数对应的映射仍很敏感；也可能满足严格等变性，却因结构约束过强而无法表达任务所需关系。

本节只说明算子结构可检查的代数关系。后续神经网络模型部分仍须定义具体层、状态、注意机制或消息传递过程，并说明计算代价与任务证据。等变性不推出不变性，局部 Jacobian 矩阵界不推出全局鲁棒性，状态稳定也不推出表示包含了预测所需的全部信息。

20.4 神经网络的训练与泛化

20.4.1 从反向求导到下降与曲率

结构规定了候选函数怎样计算，训练则要从数据中选出参数。这一步至少包含四个不同问题：导数是否算对，单步更新是否下降，带噪迭代是否长期稳定，以及最终函数是否能泛化。它们共享同一参数，却由不同数学条件支撑。

考虑一个标量输入、单隐藏单元的两层映射

$$f_{w,v}(x) = v\sigma(wx),$$

以及单样本平方损失

$$L(w, v) = \frac{1}{2} (f_{w,v}(x) - y)^2.$$

记误差 $e = v\sigma(wx) - y$ 。在 σ 可微处，链式法则给出

$$\frac{\partial L}{\partial v} = e\sigma(wx), \quad \frac{\partial L}{\partial w} = ev\sigma'(wx)x. \quad (20.6)$$

这只是导数计算。若 σ 在某点不可微，需要选用次梯度、平滑替代或明确的人为替代梯度；三种做法改变的数学对象并不相同。

这个具体网络是否满足下降引理的光滑条件，可以直接由二阶导数核对。仍令 $\theta = (w, v)^T$ ，并把 $\sigma, \sigma', \sigma''$ 都理解为在 wx 处取值。在 σ 二阶可微处，

$$\nabla^2 L(w, v) = \begin{bmatrix} v^2 x^2 (\sigma')^2 + evx^2 \sigma'' & x\sigma'(2v\sigma - y) \\ x\sigma'(2v\sigma - y) & \sigma^2 \end{bmatrix}.$$

固定 x, y ，若某个包含当前参数的凸紧邻域 U 使 wx 始终落在 σ 的二阶连续可微区间内，那么 w, v, σ, σ' 和 σ'' 在 U 上都有界，以上 Hessian 矩阵的

算子范数也有有限上界 L_U 。第 2 章的中值估计于是给出

$$\|\nabla L(\theta) - \nabla L(\theta')\|_2 \leq L_U \|\theta - \theta'\|_2, \quad \theta, \theta' \in U.$$

所以这个两层网络在该邻域内满足梯度 Lipschitz 条件, 但要使用局部常数 L_U , 还须保证更新没有离开 U 。即使 $\sigma, \sigma', \sigma''$ 全局有界, 上式中的 v^2 也说明不限制 v 时不能由此得到全局光滑常数; 若使用 ReLU 且 $x \neq 0$, 跨过 $wx = 0$ 的邻域中一般不存在上述经典 Hessian 矩阵。

设把参数合并为 $\theta = (w, v)^\top$, 目标 $F(\theta)$ 的梯度是 L_F -Lipschitz 的。梯度更新

$$\theta^{(t+1)} = \theta^{(t)} - \eta \nabla F(\theta^{(t)})$$

结合光滑性上界可得

$$\begin{aligned} F(\theta^{(t+1)}) &\leq F(\theta^{(t)}) - \eta \|\nabla F(\theta^{(t)})\|_2^2 + \frac{L_F \eta^2}{2} \|\nabla F(\theta^{(t)})\|_2^2 \\ &= F(\theta^{(t)}) - \eta \left(1 - \frac{L_F \eta}{2}\right) \|\nabla F(\theta^{(t)})\|_2^2. \end{aligned} \quad (20.7)$$

当 $0 < \eta < 2/L_F$ 时, 右端不增。第 3 章给出了这种下降论证及凸性、PL 条件等进一步接口; 非凸目标仅有单步下降, 通常不足以推出到达全局最优解。

示例 20.5 步长跨过下降范围 对 $F(\theta) = \theta^2/2$, 梯度为 θ 且 $L_F = 1$ 。更新后 $\theta^{(t+1)} = (1 - \eta)\theta^{(t)}$, 因而

$$\frac{F(\theta^{(t+1)})}{F(\theta^{(t)})} = (1 - \eta)^2.$$

取 $\eta = 1$ 时一步到达零点, 取 $\eta = 3$ 时目标放大为原来的四倍。梯度方向没有算错, 失败来自步长不满足下降条件。

曲率矩阵的谱决定不同方向上的尺度差异。若局部二次模型中的 Hessian 矩阵 $\mathbf{H} = \mathbf{H}^\top > \mathbf{0}$, 且近似为

$$F(\theta + \Delta) \approx F(\theta) + \langle \nabla F(\theta), \Delta \rangle + \frac{1}{2} \Delta^\top \mathbf{H} \Delta,$$

那么 $\mathbf{H}$ 的最大与最小特征值之比较刻画各方向的曲率尺度; 条件数较大时, 统一步长受最大曲率方向限制, 而在小曲率方向上推进较慢。取对称正定矩阵 $\mathbf{P} \in \mathbb{R}^{2 \times 2}$, 预条件更新

$$\theta^{(t+1)} = \theta^{(t)} - \eta \mathbf{P}^{-1} \nabla F(\theta^{(t)})$$

试图改变局部坐标中的尺度。第 6 章说明 $\mathbf{P}$ 的谱与数值求解条件; 具体下降保证仍须结合预条件后的谱界和步长。若 $\mathbf{H}$ 不定, 则还存在负曲率方

向，不能沿用正定二次模型的条件数解释，下降与收敛也需要另行分析。

20.4.2 从小批量梯度到随机逼近和分布几何

第 11 章把 Fisher 度量解释为参数变化引起的局部分布变化。经验梯度的二阶矩只有在相应概率模型与取期望条件下才与 Fisher 信息对应，不能仅因矩阵外形相同便互换。

示例 20.6 同一参数点上的三种二次量 沿用上一小节的两层映射，取 $\sigma(u) = u$ 、 $x = 1$ ，并把 $f_{w,v}(x) = uv$ 作为 Bernoulli 模型的对数几率：

$$p_{\theta}(Y = 1 | x) = \frac{1}{1 + \exp\{-f_{w,v}(x)\}}.$$

在 $\theta_0 = (1, \log 4)^T$ 处，正类概率为 $p = 0.8$ ，且

$$\mathbf{J} = \nabla_{\theta} f_{\theta_0}(x) = \begin{bmatrix} \log 4 \\ 1 \end{bmatrix}.$$

对同一小扰动 $\Delta = (\varepsilon, 0)^T$ ，欧氏参数距离只记录坐标变化，

$$\|\Delta\|_2^2 = \varepsilon^2.$$

若当前观察到 $Y = 1$ ，负对数似然梯度为 $\mathbf{g}_1 = (p - 1)\mathbf{J} = -0.2\mathbf{J}$ 。这个观测形成的梯度二阶矩为 $\mathbf{G}_{\text{obs}} = \mathbf{g}_1\mathbf{g}_1^T$ ，故

$$\Delta^T \mathbf{G}_{\text{obs}} \Delta = 0.04(\log 4)^2 \varepsilon^2 \approx 0.0769 \varepsilon^2.$$

Fisher 信息则对模型自身的随机标签取期望：

$$\mathbf{F}(\theta_0) = \mathbb{E}_{Y \sim p_{\theta_0}} [\mathbf{g}_Y \mathbf{g}_Y^T] = p(1 - p)\mathbf{J}\mathbf{J}^T,$$

因而

$$\Delta^T \mathbf{F}(\theta_0) \Delta = 0.16(\log 4)^2 \varepsilon^2 \approx 0.3075 \varepsilon^2.$$

三个量在同一参数点和同一方向上仍不相等：欧氏距离依赖参数坐标，观测梯度二阶矩依赖实际样本，Fisher 二次型则是模型分布下得分的期望，它的一半给出局部 KL 变化的二阶主项。只有损失确为该模型的负对数似然，并按模型分布对观测取期望时，后两种矩阵才对应。

小批量训练把精确梯度改成随机估计

$$\mathbf{g}^{(t)} = \nabla F(\theta^{(t)}) + \xi^{(t)}.$$

若条件均值满足 $\mathbb{E}[\xi^{(i)} | \mathcal{F}_i] = \mathbf{0}$, 步长满足相应求和条件, 并且迭代有界或存在稳定机制, 第9章的随机逼近工具可把更新与平均动力学联系起来。批量改变时, 噪声方差和相关结构也会改变; 仅验证无偏, 不能替代矩条件、步长和稳定性。

20.4.3 从训练收敛到新样本表现

即使训练目标持续下降, 也只说明当前数据上的求解行为。把训练所得函数用于新样本, 需要回到式(8.25)一类泛化工具, 或采用函数类复杂度、稳定性和信息控制等其他路径。参数数量、参数范数、谱量和优化轨迹可以成为分析量, 但任何一个量单独变小都不自动推出总体风险变小。

后续神经网络训练章节会指定初始化、归一化、数据变换、损失与停止规则, 深度学习理论则针对具体函数类和随机算法建立结论。本节的边界是: 式(20.6)只保证局部导数正确, 式(20.7)只在光滑性和步长条件下保证单步变化, 随机逼近讨论长期迭代, 而泛化仍需单独的数据生成假设。

20.5 概率模型的推断、学习与生成

20.5.1 从联合模型到条件查询和结构计算

概率模型中的“计算概率”“从数据估计参数”和“生成新样本”常使用同一个联合分布, 却回答三个不同问题。先固定一个含隐变量的简单模型, 可以看清边缘化、条件化、参数学习和采样各自改变了什么。

设隐变量 $Z \in \{0, 1\}$, 观测 $X \in \{0, 1\}$,

$$\mathbb{P}(Z = 1) = \pi, \quad \mathbb{P}(X = 1 | Z = z) = \theta_z.$$

参数 π, θ_0, θ_1 给定时, 边缘概率由全概率公式得到

$$\mathbb{P}(X = 1) = (1 - \pi)\theta_0 + \pi\theta_1.$$

观察到 $X = 1$ 后, 对隐状态的条件推断为

$$\mathbb{P}(Z = 1 | X = 1) = \frac{\pi\theta_1}{(1 - \pi)\theta_0 + \pi\theta_1}. \quad (20.8)$$

这里没有学习参数, 只是对给定联合分布执行求和与条件化。

示例 20.7 同一联合分布上的三个问题 取 $\pi = 1/4$, $\theta_0 = 1/5$, $\theta_1 = 4/5$ 。则

$$\mathbb{P}(X = 1) = \frac{3}{4} \cdot \frac{1}{5} + \frac{1}{4} \cdot \frac{4}{5} = \frac{7}{20},$$

且

$$\mathbb{P}(Z = 1 | X = 1) = \frac{(1/4)(4/5)}{7/20} = \frac{4}{7}.$$

推断问的是已见 $X = 1$ 时 Z 如何分布；学习会把三个参数视为未知；生成则先抽 Z ，再按对应 θ_Z 抽 X 。三个过程共用因子，输入、输出和正确性标准却不同。

变量增多后，直接枚举联合状态的代价可能迅速增大。第 14 章中的分离、消元与分配结构把全局求和重组为局部运算。计算量取决于消元过程中形成的中间作用域，而不只取决于原图有多少条边。连续变量还要核对积分交换与可积性；线性高斯结构可利用第 6 章的 Schur 补，动态结构则可复用第 16 章的预测、滤波与平滑递推。

同一联合分解还会因查询目标不同而使用不同运算。计算某个变量的边缘概率时，需要对其余变量求和；求联合最大后验配置时，要把消元中的求和改为最大化，并保存每一步的最优见证以便回溯出彼此兼容的联合配置。逐时边缘最优状态则先分别计算各时刻的边缘分布，再在每个边缘上取最大值；这些状态通常不能直接拼成联合概率最大的整条路径。求和与最大化一般不可交换，因此图结构只规定可利用的分解，查询目标还决定消元代数、回溯信息和最终输出。

20.5.2 从精确查询到三类近似

精确边缘难以计算时，可以引入近似分布 $q(z)$ 。假设 $0 < p(x) < \infty$ ，并且 q 与后验 $p(\cdot | x)$ 具有相同支撑，即 $q(z) > 0$ 当且仅当 $p(x, z) > 0$ ；再假设下述期望与 KL 散度有限，则

$$\begin{aligned} \log p(x) &= \log \sum_z q(z) \frac{p(x, z)}{q(z)} \\ &\geq \sum_z q(z) \log \frac{p(x, z)}{q(z)} = \mathcal{L}(q), \end{aligned} \quad (20.9)$$

其中不等式来自对数函数的凹性。进一步整理可得

$$\log p(x) - \mathcal{L}(q) = \text{KL}(q(z) \| p(z | x)).$$

因此优化变分下界等价于在所选 q 族内逼近后验，但只有当 q 族包含真实后验且优化到全局最优时，间隙才必为零。第 11 章提供 KL 散度与变分表达，第 3 章提供交替和分布优化的求解接口。

另一条路径是用样本平均近似期望。若 $Z^{(1)}, \dots, Z^{(N)}$ 来自目标分布且二

阶矩有限,

$$\hat{\mu}_N = \frac{1}{N} \sum_{j=1}^N f(Z^{(j)})$$

在独立抽样下具有方差 $\text{Var}(f(Z))/N$ 。若样本来自 Markov 链, 相关性会改变有效方差, 需要第 9 章的遍历与相关平均条件。链保持目标分布并不说明有限步已经充分混合, 有限样本误差也不能由平稳性一项保证。

连续后验还可以在众数附近作局部二次展开。若

$$\hat{\mathbf{z}} \in \arg \max_{\mathbf{z}} \log p(\mathbf{z} | x), \quad \mathbf{H} = -\nabla_{\mathbf{z}}^2 \log p(\hat{\mathbf{z}} | x)$$

且 $\hat{\mathbf{z}}$ 是内点、 $\mathbf{H}$ 正定, 二阶 Taylor 展开给出局部高斯近似

$$p(\mathbf{z} | x) \approx \mathcal{N}(\hat{\mathbf{z}}, \mathbf{H}^{-1}).$$

第 10 章的 Laplace 近似说明, 还需有足够光滑性, 并且后验主要质量确由该邻域控制。多峰、边界众数或退化曲率都会破坏这一近似。变分法限制分布族, 采样法以随机平均逼近期望, Laplace 方法只保留局部曲率; 三者改变的对象和误差来源不同。

示例 20.8 同一后验上的三种近似 取先验 $p \sim \text{Beta}(2, 2)$, 观察四次 Bernoulli 试验中的三次成功, 则同一个精确后验为

$$p | \mathbf{y} \sim \text{Beta}(5, 3), \quad \mathbb{E}[p | \mathbf{y}] = \frac{5}{8}, \quad \text{Var}(p | \mathbf{y}) = \frac{15}{576}.$$

以下记其密度为 $\pi(p | \mathbf{y})$ 。若变分族取全部 Beta 分布, ELBO 的全局最优解就是 $q^* = \text{Beta}(5, 3)$, 其分布逼近误差 $\text{KL}(q^* || \pi(\cdot | \mathbf{y}))$ 为零。这个结果依赖候选族包含精确后验; 换成受限族后, ELBO 间隙衡量的是所选方向的 KL 误差。

若能独立采样, N 个后验样本的均值估计后验均值, 其 Monte Carlo 标准误为

$$\sqrt{\frac{15}{576N}}.$$

取 $N = 100$ 时约为 0.0161。这里控制的是某个后验期望的随机积分误差, 不是一个固定近似密度与精确后验之间的距离。

Laplace 方法在后验众数 $\hat{p} = 2/3$ 处展开。负对数后验的局部曲率为

$$-\left. \frac{d^2}{dp^2} \log \pi(p | \mathbf{y}) \right|_{p=2/3} = \frac{4}{(2/3)^2} + \frac{2}{(1/3)^2} = 27,$$

因而得到 $\mathcal{N}(2/3, 1/27)$ 。其均值相对精确后验偏高 $1/24$ ，方差相差

$$\frac{1}{27} - \frac{15}{576} = \frac{19}{1728} \approx 0.0110.$$

它还把少量质量放到参数区间 $[0, 1]$ 之外。Laplace 误差来自局部二次形状无法完整表示偏斜与边界，而非有限样本平均的随机波动。

20.5.3 从参数估计到样本构造

参数未知时，问题转为根据观测识别和估计 π, θ_0, θ_1 。仅观察 X 时，不同参数组合可能产生同一个边缘 Bernoulli 概率，所以更多样本只能更精确地估计这个边缘量，不能自动区分不可识别的参数。第 10 章把识别、似然、缺失机制和估计误差分开；交替优化只能求解给定目标，不能修复目标本身的不可识别性。

在这个隐变量模型中，交替精确更新为何单调改善观测似然也可以就地核对。对观测 $x_1, \dots, x_n$ ，记参数为 $\boldsymbol{\vartheta} = (\pi, \theta_0, \theta_1)$ ，并定义

$$\ell_{\text{obs}}(\boldsymbol{\vartheta}) = \sum_{i=1}^n \log \sum_{z \in \{0,1\}} p_{\boldsymbol{\vartheta}}(x_i, z).$$

设各次迭代中的边缘似然严格为正且有限，后验和下列期望均有定义，并且两个条件子问题的最优解能够达到。精确 E 步和 M 步分别取

$$q_i^{(t+1)}(z) = p_{\boldsymbol{\vartheta}^{(t)}}(z \mid x_i), \quad \boldsymbol{\vartheta}^{(t+1)} \in \arg \max_{\boldsymbol{\vartheta}} \mathcal{L}(\boldsymbol{q}^{(t+1)}, \boldsymbol{\vartheta}),$$

其中

$$\mathcal{L}(\boldsymbol{q}, \boldsymbol{\vartheta}) = \sum_{i=1}^n \sum_z q_i(z) \log \frac{p_{\boldsymbol{\vartheta}}(x_i, z)}{q_i(z)}.$$

变分恒等式给出

$$\ell_{\text{obs}}(\boldsymbol{\vartheta}) = \mathcal{L}(\boldsymbol{q}, \boldsymbol{\vartheta}) + \sum_{i=1}^n \text{KL}(q_i \parallel p_{\boldsymbol{\vartheta}}(\cdot \mid x_i)).$$

E 步使右端的 KL 项在 $\boldsymbol{\vartheta}^{(t)}$ 处为零，M 步又精确提高同一个下界，因而

$$\begin{aligned} \ell_{\text{obs}}(\boldsymbol{\vartheta}^{(t)}) &= \mathcal{L}(\boldsymbol{q}^{(t+1)}, \boldsymbol{\vartheta}^{(t)}) \\ &\leq \mathcal{L}(\boldsymbol{q}^{(t+1)}, \boldsymbol{\vartheta}^{(t+1)}) \\ &\leq \ell_{\text{obs}}(\boldsymbol{\vartheta}^{(t+1)}). \end{aligned}$$

这就是单调改善的完整理由；一般交替与主化-最小化论证见第 3 章。等号可以连续成立，所以该链条不保证严格改善，也不保证到达全局最大值。若 E 步不是当前参数的精确后验，或 M 步没有提高同一个 $\mathcal{L}$ ，上述两处

依据都要重新检查。

生成样本又改变了输出要求。可逆变换依赖 Jacobian 矩阵与密度换元, 连续随机生成依赖布朗运动、随机微分与密度演化, 而直接祖先采样依赖图中的条件分解。一个过程具有正确的不变分布、一个变分目标足够高, 或一个数值积分器局部误差较小, 都不能单独替代对生成分布与任务质量的评价。后续概率图模型部分将定义具体表示与算法; 本节只建立区分建模误差、推断误差、参数误差、采样误差和数值误差的框架。

20.6 可信机器学习

20.6.1 从预测误差到覆盖与验证证据

平均预测误差只回答随机抽取一个样本时的平均表现。可信机器学习会进一步询问: 预测范围是否覆盖未来结果, 输入受扰动后输出是否稳定, 不同群组或干预目标是否得到规定保障, 算法输出是否泄露单个数据主体的信息。这些要求没有共同的单一分数, 必须先固定保护或保证的对象。

先看有限样本预测覆盖。设有 n 个校准分数 $S_1, \dots, S_n$ 和一个未来分数 S_{n+1} , 且 $n+1$ 个分数可交换。若分数越大表示预测越不相容, 令

$$k = \lceil (n+1)(1-\alpha) \rceil,$$

当 $k \leq n$ 时取排序阈值 $q = S_{(k)}$, 并令预测集合包含所有分数不超过 q 的候选结果; 当 $k = n+1$ 时约定 $q = +\infty$, 即返回整个候选结果空间。后一约定处理 $\alpha < 1/(n+1)$ 的极端置信水平, 此时有限校准样本无法给出非平凡的分布无关集合。由于未来分数的秩在无并列的情形下均匀分布于 $\{1, \dots, n+1\}$,

$$\mathbb{P}(S_{n+1} \leq q) = \begin{cases} k/(n+1), & k \leq n, \\ 1, & k = n+1, \end{cases} \geq 1-\alpha. \quad (20.10)$$

有并列时采用适当随机化或保守规则, 仍可得到相应覆盖结论。

示例 20.9 四个可交换分数的秩 设 $n=3$ 、 $\alpha=1/4$, 三个校准分数排序后为 0.2, 0.5, 0.9。此时 $k = \lceil 4 \times 3/4 \rceil = 3$, 阈值为 0.9。若四个分数可交换且没有并列, 未来分数落在前三级秩中的概率为 $3/4$ 。这个计算给出边缘覆盖; 它没有声称对每个固定输入、每个群组或每个时间点都具有 $3/4$ 的条件覆盖。

式 (20.10) 依赖可交换性与预先规定的构造。若校准样本与未来样本来自不同分布, 或者反复查看校准表现后选择分数函数, 秩的对称性会被破

坏。第 8 章提供可交换秩，第 10 章则说明数据划分、模型选择、多重比较与持续查看怎样影响证据。总体覆盖不能仅通过按群组报告平均值升级为条件覆盖。

20.6.2 从允许扰动到群组与行为要求

鲁棒性把问题改成允许输入在集合内变化时，输出最多改变多少。若可微标量函数 f 在 $\mathbf{x}$ 附近作一阶展开，

$$f(\mathbf{x} + \boldsymbol{\delta}) - f(\mathbf{x}) \approx \langle \nabla f(\mathbf{x}), \boldsymbol{\delta} \rangle.$$

对约束 $\|\boldsymbol{\delta}\|_p \leq \varepsilon$ ，对偶范数关系给出

$$\sup_{\|\boldsymbol{\delta}\|_p \leq \varepsilon} \langle \nabla f(\mathbf{x}), \boldsymbol{\delta} \rangle = \varepsilon \|\nabla f(\mathbf{x})\|_q, \quad \frac{1}{p} + \frac{1}{q} = 1. \quad (20.11)$$

第 5 章给出范数与对偶范数，第 3 章把扰动集合接入约束或鞍点目标。式 (20.11) 是线性项的精确最坏变化；对有限扰动下的非线性模型，还要控制 Taylor 余项或给出有效的全局 Lipschitz 界。

公平性可能要求比较群组条件错误率，也可能要求某种干预或反事实量。前者依赖条件概率及分母，后者还依赖第 12 章的识别假设。仅让两个观测群组的某项平均相等，不能推出个体在干预意义下受到相同处理。行动补救也不只是寻找梯度方向：候选改变必须可实施，并且改变后预测的因果含义需要由结构假设支持。

对齐、拒答和安全决策把概率输出继续接到损失、行动与风险。第 17 章说明同一预测分布可以对应不同错误代价和风险准则，第 18 章则区分长期稳定、成本最优与安全集合保持。

20.6.3 从数据变化到隐私与解释对象

隐私保护则比较相邻数据集 D, D' 下随机算法的输出分布。给定一个对称的相邻关系，若 $\epsilon \geq 0$ 、 $\delta \in [0, 1]$ ，且随机机制 $\mathcal{M}$ 对任意相邻的 D, D' 和任意可测输出事件 A 都满足

$$\mathbb{P}(\mathcal{M}(D) \in A) \leq e^\epsilon \mathbb{P}(\mathcal{M}(D') \in A) + \delta,$$

就称 $\mathcal{M}$ 满足 (ϵ, δ) -差分隐私 (differential privacy, DP)。其中 e^ϵ 限制输出概率的乘性变化， δ 允许一个加性例外；两者越小，相邻数据集的输出分布越难区分。应用这一定义前，研究者必须先说明何种数据变化构成相邻。改变保护单位会改变敏感度与噪声尺度；分布差异和信息控制可以组织证明，但不能替代威胁模型。类似地，可解释性中的局部导数、估计影响和联盟贡献分别解释输入敏感性、训练过程与预先定义的价值函数，不能共

用一个含混的“重要性”概念。

示例 20.10 同一预测上的三种解释对象 考虑带交互项的预测

$$f_{\mathbf{w}}(\mathbf{x}) = w_1x_1 + w_2x_2 + w_{12}x_1x_2, \quad \mathbf{w} = (1, 2, 1)^\top,$$

并解释目标输入 $\mathbf{x} = (1, 1)^\top$ 处的预测 $f_{\mathbf{w}}(\mathbf{x}) = 4$ 。局部导数把训练结果 $\mathbf{w}$ 固定，只改变输入的第二个特征：

$$\frac{\partial f_{\mathbf{w}}}{\partial x_1}(1, 1) = w_1 + w_{12}x_2 = 2.$$

它表示 x_1 在该点每作一个无穷小单位变化时，预测的一阶变化率。

影响函数改变的是训练分布。为使数值可复核，设单点损失为半平方损失

$$\ell(\mathbf{w}; (\mathbf{x}, y)) = \frac{1}{2}(f_{\mathbf{w}}(\mathbf{x}) - y)^2,$$

$\mathbf{w}$ 由相应总体风险估计，且该总体风险的参数 Hessian 矩阵在当前解处为 $\mathbf{I}_3$ 。若给训练点 $\mathbf{z} = ((1, 0)^\top, 4)$ 增加无穷小概率质量，则该点的参数梯度为

$$\nabla_{\mathbf{w}} \ell(\mathbf{w}; \mathbf{z}) = (f_{\mathbf{w}}(1, 0) - 4) \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix} = \begin{bmatrix} -3 \\ 0 \\ 0 \end{bmatrix}.$$

第 10 章的影响函数公式给出参数的一阶变化 $3(1, 0, 0)^\top$ ，进而使目标输入处的预测以速率 3 变化。这里被扰动的是训练点权重，而不是目标输入的 x_1 。

Shapley 解释还要先指定缺失特征的基线。取零基线并令 $v(S) = f_{\mathbf{w}}(\mathbf{x}_S, \mathbf{0}_{\bar{S}}) - f_{\mathbf{w}}(\mathbf{0})$ ，则

$$v(\emptyset) = 0, \quad v(\{1\}) = 1, \quad v(\{2\}) = 2, \quad v(\{1, 2\}) = 4.$$

第 19 章的两人 Shapley 公式因此给出

$$\phi_1 = \frac{1}{2}[(1 - 0) + (4 - 2)] = \frac{3}{2}, \quad \phi_2 = \frac{5}{2}.$$

它把相对基线的有限预测差 4 分配给两个特征，并把交互项在两种加入次序间平均。数值 2, 3, 3/2 不同并非矛盾：三者分别回答局部输入扰动、训练分布污染和基于指定联盟价值的有限贡献。

后续可信性章节仍须逐项规定保护对象、威胁条件、数据协议和验证程序。本节给出的覆盖与扰动推导不能被拼成一个无定义的总体可信保证。

20.7 强化学习与序贯决策

20.7.1 从两步决策到固定点与占用流量

监督预测把数据分布视为给定，序贯决策中的行动却会改变后续状态和未来数据。因此，价值递推、随机逼近、探索证据、离线支持和安全约束必须要在同一个时间结构中分别核对²。先从一个已知模型的两阶段过程出发，可以确定动态规划究竟解决了哪一步。

² R. S. Sutton, A. G. Barto, *Reinforcement Learning: An Introduction*, MIT Press, 2018, 2nd ed.

设初始状态为 s ，可选行动 a ，即时奖励为 $r(s, a)$ ，下一状态按 $P(s' | s, a)$ 分布。最后阶段的价值为

$$V_1(s) = \max_a r_1(s, a).$$

初始阶段的最优价值则为

$$V_0(s) = \max_a \left\{ r_0(s, a) + \sum_{s'} P(s' | s, a) V_1(s') \right\}. \quad (20.12)$$

这一步来自条件期望和“在下一状态到达后再选择”的信息顺序。若初始行动必须在看见 s' 之前同时承诺第二步行动，最大值与期望的次序就会改变。

示例 20.11 即时奖励与未来价值 初始状态有行动 a 和 b 。行动 a 立即得到 1，随后以相同概率到达终局价值 0 或 4 的状态；行动 b 立即得到 2，随后确定到达终局价值 1 的状态。由式 (20.12)，

$$Q_0(s, a) = 1 + \frac{0 + 4}{2} = 3, \quad Q_0(s, b) = 2 + 1 = 3.$$

两个行动的期望价值相同，但尾部风险不同。若改用动态风险准则，还要明确条件风险怎样逐阶段嵌套，不能只把期望符号替换为一个静态风险数。

在折扣无限时域中，对有界函数 V 定义 Bellman 最优算子

$$(\mathcal{T}V)(s) = \max_a \left\{ r(s, a) + \gamma \sum_{s'} P(s' | s, a) V(s') \right\}, \quad 0 \leq \gamma < 1.$$

利用最大值的差不超过对应项最大差，可得

$$\|\mathcal{T}V - \mathcal{T}W\|_\infty \leq \gamma \|V - W\|_\infty.$$

第 2 章的压缩映射定理于是给出固定点唯一性与值迭代误差收缩。这个结论以已知转移核、奖励有界和 $\gamma < 1$ 为前提；平均回报、无折扣或连续状态问题需要不同的空间与条件。

同一个有限状态、有限动作的折扣问题还可从流量角度表达。给定归一化初始分布 ρ ，以 $(1 - \gamma) \sum_s \rho(s) V(s)$ 为最小化目标，并加入价值不等式

$$V(s) \geq r(s, a) + \gamma \sum_{s'} P(s' | s, a) V(s')$$

组成一个线性规划；其对偶变量 $d(s, a) \geq 0$ 满足

$$\sum_a d(s, a) = (1 - \gamma) \rho(s) + \gamma \sum_{\bar{s}, \bar{a}} d(\bar{s}, \bar{a}) P(s | \bar{s}, \bar{a}). \quad (20.13)$$

对所有状态求和可核对 $\sum_{s,a} d(s, a) = 1$ ，所以 d 表示归一化折扣占用流量；对偶目标是最大化 $\sum_{s,a} d(s, a) r(s, a)$ 。第 3 章的线性规划对偶与第 17 章的占用度量共同说明，价值函数和访问流量是同一已知模型规划问题的两侧。转移核未知时，这个等价关系并没有说明如何取得满足守恒约束所需的数据。

20.7.2 从随机观测到价值和策略更新

模型未知时，期望只能由交互数据近似。例如一次时序差分更新可写为

$$V^{(t+1)}(S_t) = V^{(t)}(S_t) + \alpha_t (R_t + \gamma V^{(t)}(S_{t+1}) - V^{(t)}(S_t)).$$

括号中的量不是独立同分布噪声，因为状态由策略驱动的 Markov 链产生。第 9 章提供鞅差、Markov 噪声和步长条件，第 16 章把平均更新写成 ODE 并检查漂移稳定性。同策略线性逼近下的稳定分析不能直接搬到离策略、非线性或持续变化的环境。

把这句话落实到可检查的平均漂移。令 $V_\theta(s) = \phi(s)^\top \theta$ ，把各状态特征按行组成 Φ 。固定策略 π 诱导有限状态转移矩阵 P_π ，并假设样本链已经处于平稳分布 $\mathbf{d}$ ，记 $\mathbf{D} = \text{diag}(\mathbf{d})$ 。行为策略与被评价策略同为 π 时，

$$\bar{\mathbf{h}}(\theta) = \mathbb{E}[\phi(S_t)(R_t + \gamma \phi(S_{t+1})^\top \theta - \phi(S_t)^\top \theta)] = \mathbf{b} - \mathbf{A}_{\text{TD}} \theta,$$

$$\mathbf{b} = \Phi^\top \mathbf{D} \mathbf{r}_\pi, \quad \mathbf{A}_{\text{TD}} = \Phi^\top \mathbf{D} (\mathbf{I} - \gamma \mathbf{P}_\pi) \Phi.$$

这里 $\mathbf{r}_\pi$ 是固定策略在各状态下的一步期望奖励向量。平稳性使 $\mathbf{P}_\pi$ 在 $\mathbf{D}$ 加权二范数下非扩张。若 $0 \leq \gamma < 1$ 且特征在实际访问分布下非退化，即 $\Phi^\top \mathbf{D} \Phi > \mathbf{0}$ ，那么对任意 $\mathbf{c} \neq \mathbf{0}$ ，

$$\mathbf{c}^\top \mathbf{A}_{\text{TD}} \mathbf{c} \geq (1 - \gamma) \|\Phi \mathbf{c}\|_{\mathbf{D}}^2 > 0.$$

因此 $\mathbf{A}_{\text{TD}}$ 的对称部分正定，平均 ODE $\dot{\theta} = \mathbf{b} - \mathbf{A}_{\text{TD}} \theta$ 具有唯一的全局指数稳定平衡。加权非扩张与 Lyapunov 核对已在第 16 章完整给出，这里不重复证明。从平均 ODE 走向随机 TD 迭代，还需要 $\sum_t \alpha_t = \infty$ 、 $\sum_t \alpha_t^2 < \infty$ ，

以及相应的噪声矩、Markov 混合和迭代有界条件。若没有平稳采样，有限时间均值还含初始分布的过渡项；若改成离策略采样， $\mathbf{D}$ 与 $\mathbf{P}_\pi$ 不再配套，上述非扩张步骤可能失效。

若目标改为直接调整参数化策略 π_θ ，取不依赖 θ 的初始分布 ρ_0 和环境转移核 P 。有限时域轨迹 $\tau = (S_0, A_0, \dots, A_{T-1}, S_T)$ 的概率分解为

$$p_\theta(\tau) = \rho_0(S_0) \prod_{t=0}^{T-1} \pi_\theta(A_t | S_t) P(S_{t+1} | S_t, A_t).$$

再令

$$G(\tau) = \sum_{t=0}^{T-1} \gamma^t r_t(S_t, A_t), \quad J(\theta) = \mathbb{E}_{\tau \sim p_\theta}[G(\tau)].$$

这里奖励函数 r_t 不显含 θ ，所以 G 对参数的依赖只来自轨迹分布。若 G 可积、策略关于 θ 可微、策略支持集不随 θ 改变，并且允许交换求导与积分，对上述乘积分布使用对数导数便得到

$$\nabla_\theta J(\theta) = \mathbb{E}_{\tau \sim p_\theta} \left[G(\tau) \sum_{t=0}^{T-1} \nabla_\theta \log \pi_\theta(A_t | S_t) \right]. \quad (20.14)$$

若初始分布、环境动力学或奖励本身也显式依赖 θ ，相应对数导数或 $\nabla_\theta G_\theta(\tau)$ 项必须保留，不能只写策略得分之和。若基线 $b_t(S_t)$ 只依赖当前状态，不依赖尚未抽取的 A_t ，则

$$\mathbb{E}[b_t(S_t) \nabla_\theta \log \pi_\theta(A_t | S_t) | S_t] = b_t(S_t) \nabla_\theta \sum_a \pi_\theta(a | S_t) = \mathbf{0}.$$

因此这类基线可以降低方差而不改变期望梯度；依赖当前动作的任意基线没有这一保证。第 11 章的 Fisher 度量进一步按局部策略分布变化缩放式 (20.14)，所得自然梯度不能与任意经验梯度二阶矩预条件混为一谈。

20.7.3 从自适应采样到探索与复杂度

探索又改变了数据生成策略。自归一化集中可以利用实际访问形成的设计矩阵，但仍需可预测性、噪声条件和足够激励；信息论下界说明某些环境在有限交互中难以区分。

示例 20.12 自适应两动作探索中的置信与访问预算 设单状态中有两个动作 A, B ，Bernoulli 奖励的均值分别为 $\mu_A = 0.6$ 与 $\mu_B = 0.5$ ，并假设给定过去与当前动作后，奖励仍服从相应参数的 Bernoulli 分布。在第 t 轮，算法根据 $\mathcal{F}_{t-1}$ 中的历史选择动作 A_t ，再观察奖励 Y_t 。对动作 a ，

$$X_{t,a} = \mathbb{I}\{A_t = a\}(Y_t - \mu_a)$$

是有界鞅差, 其可预测方差累计量为 $\mu_a(1-\mu_a)N_a(t)$, 其中 $N_a(t)$ 是截至 t 的实际访问次数。因而第9章的 Freedman 界按 $N_a(t)$ 及实际条件方差控制误差, 而不是把随机访问序列误当作预先固定样本。

两个动作还可写成一个自归一化线性模型。令 $\theta^* = (\mu_A, \mu_B)^\top$, 选择动作时取 $\mathbf{x}_t = \mathbf{e}_{A_t}$, 并写成

$$Y_t = \langle \mathbf{x}_t, \theta^* \rangle + \eta_t.$$

Bernoulli 中心化噪声条件 $1/2$ -次高斯, 且 $\mathbf{x}_t$ 在当前奖励出现前已经确定。取正则参数 $\lambda = 1$ 和 $\|\theta^*\|_2 \leq B = 1$, 设计矩阵为

$$\mathbf{V}_t = \mathbf{I} + \begin{bmatrix} N_A(t) & 0 \\ 0 & N_B(t) \end{bmatrix}.$$

令

$$\hat{\theta}_t = \mathbf{V}_t^{-1} \sum_{s=1}^t \mathbf{x}_s Y_s = \begin{bmatrix} \hat{\mu}_A \\ \hat{\mu}_B \end{bmatrix}$$

为相应的岭估计。自归一化置信椭圆以至少 $1 - \delta$ 的概率对所有 t 同时满足

$$\|\hat{\theta}_t - \theta^*\|_{\mathbf{V}_t} \leq \beta_t(\delta) = \frac{1}{2} \sqrt{2 \log \frac{\sqrt{(1+N_A(t))(1+N_B(t))}}{\delta}} + 1.$$

于是均值差 $\Delta = \mu_A - \mu_B$ 的统计误差由实际访问数决定:

$$|(\hat{\mu}_A - \hat{\mu}_B) - \Delta| \leq \beta_t(\delta) \sqrt{\frac{1}{1+N_A(t)} + \frac{1}{1+N_B(t)}}.$$

记上式右端为 r_t , 并记估计差为 $\hat{\Delta}_t = \hat{\mu}_A - \hat{\mu}_B$ 。取 $\delta = 0.05$ 。若某一时刻实际有 $N_A = N_B = 2200$, 则 $\beta_t \approx 3.312$, 且 $r_t \approx 0.0998$, 略小于真实间隔 $\Delta = 0.1$ 。因此在该置信事件上 $\hat{\Delta}_t \geq \Delta - r_t > 0$, 点估计的符号保持正确。但投影置信区间 $[\hat{\Delta}_t - r_t, \hat{\Delta}_t + r_t]$ 是否排除零, 还要检查实际观测是否满足 $\hat{\Delta}_t > r_t$ 。若只根据真实间隔和误差界预先保证整个置信集合都区分两个动作, 一个充分条件是 $2r_t < \Delta$; 当前访问数并不满足这个更强条件。

访问预算是另一项要求。一个强制两边各访问 2200 次的协议需要至少 4400 次交互; 仅给出总预算 $t = 4400$ 却不规定探索分配, 可能出现 $N_B(t) = 0$, 此时上述半径仍含 $1/(1+N_B(t)) = 1$, 无法辨认动作 B 。前一个不等式回答“给定已经实现的设计, 统计误差多大”, 探索协议则回答“用多少次交互才能实现足够的设计”。二者必须分开报告。

函数类复杂度或低秩结构只有与可实现性、访问协议和 Bellman 残差等具体对象结合，才能转化为样本效率结论。具体地，先把候选价值与其 Bellman 更新之差定义为残差，再在某个数据生成规则下取期望；若这个由“候选函数—数据规则”索引的二元量可分解为 d 维向量内积， d 才构成 Bellman 秩分析的入口。普通矩阵低秩本身既没有定义这个残差，也不保证学习者会访问辨认它所需的状态与行动。

20.7.4 从信息和反馈限制到识别边界

部分观测要求把历史压缩为足以决策的状态或条件分布。固定日志下的离线评价还要求目标策略的轨迹分布被日志策略覆盖；若某个行动在日志中概率为零，重要性权重无法恢复其结果。因果部分识别可以描述支持不足时仍可确定的范围，却不能凭借更复杂的拟合补出从未观测的行动后果。

奖励并不总是被直接记录。给定轨迹回报

$$R_{\theta}(\tau) = \sum_{t=0}^{T-1} \gamma^t r_{\theta}(S_t, A_t),$$

示范数据需要先规定“何种奖励会产生何种行为”。一种可检验的最大熵接口以环境动力学形成的基准轨迹测度 $\mu(\tau)$ 为底；当 $0 < Z(\theta, \beta) < \infty$ 时，写成

$$p_{\theta, \beta}(\tau) = \frac{\mu(\tau) \exp\{\beta R_{\theta}(\tau)\}}{Z(\theta, \beta)}.$$

偏好反馈则可把同一回报差接到二元选择概率：

$$\mathbb{P}_{\theta, \beta}(\tau^+ > \tau^-) = \frac{1}{1 + \exp\{-\beta[R_{\theta}(\tau^+) - R_{\theta}(\tau^-)]\}}. \quad (20.15)$$

在给定参数后各条反馈条件独立的模型下，示范轨迹概率和成对选择概率的乘积构成关于 (θ, β) 的似然。这把第 10 章的似然接口接到了奖励学习：数据固定后，比较的是不同奖励参数对已观察行为赋予的概率。

似然能够优化并不等于奖励可识别。若两个参数对所有允许查询产生相同的示范与偏好分布，那么只有在它们也给出相同目标量时，该目标才可识别。例如给所有轨迹回报加同一常数不会改变归一化示范概率或偏好差，因而绝对奖励零点不可识别；若 β 也未知，同时缩放回报并反向缩放 β 仍给出相同观测分布，奖励尺度也不可识别。只在已访问轨迹上收集偏好还可能留下其他行动的回报差未定。研究目标因此应明确写成可识别的回报差、行为分布、最优策略等价类或另加规范化与覆盖条件，而不能把任意一个拟合出的 r_{θ} 当作唯一真实奖励。

20.7.5 从任务与参与者变化到风险和安全

多方参与时，环境转移不再是固定背景。博弈论与多方决策章中的最佳响应、均衡、信息集和反事实遗憾分别规定允许怎样偏离以及对手如何进入比较。零和平均策略保证、一般和均衡存在与某个学习动态的最后迭代收敛不是同一结论。行为约束还会调用第 17 章的动态风险、第 16 章的 Lyapunov 稳定性和第 18 章的安全不变性。

后续强化学习部分会为规划、交互学习、离线数据、任务适应、多方决策和安全约束分别建立模型与算法。本节的数学入口要求研究者先写清四件事：优化什么回报或风险，数据由哪一个策略产生，决策时可以使用什么信息，当前结论控制价值误差、遗憾、稳定性还是逐轨迹约束。

20.8 知识的获取与融合

20.8.1 从来源答案到可靠性与可识别性

训练标签、规则和偏好并不总是直接可得。当多个来源为同一对象提供答案时，记录数量不等于独立信息量，来源置信度也不等于来源正确率。知识获取研究需要把潜在目标、来源机制和查询制度分别建模，再决定怎样融合证据。

设未知二元目标 $Y \in \{0, 1\}$ ，先验概率为 $\mathbb{P}(Y = 1) = 1/2$ 。两个来源给出 $L_1, L_2 \in \{0, 1\}$ 。先采用一个可检查的简化模型：给定 Y 后两来源条件独立，且正确率均为 $p > 1/2$ ，

$$\mathbb{P}(L_j = Y | Y) = p, \quad j = 1, 2.$$

若两来源都报告 1，Bayes 公式给出后验赔率

$$\begin{aligned} \frac{\mathbb{P}(Y = 1 | L_1 = L_2 = 1)}{\mathbb{P}(Y = 0 | L_1 = L_2 = 1)} &= \frac{\mathbb{P}(Y = 1)}{\mathbb{P}(Y = 0)} \prod_{j=1}^2 \frac{\mathbb{P}(L_j = 1 | Y = 1)}{\mathbb{P}(L_j = 1 | Y = 0)} \\ &= \left(\frac{p}{1-p} \right)^2. \end{aligned} \quad (20.16)$$

第 8 章提供联合、条件和 Bayes 公式，第 10 章则要求先判断 p 及来源关系能否由观测识别。

示例 20.13 独立来源与复制来源 取 $p = 0.8$ 。若条件独立，两次一致报告 1 产生的后验概率为

$$\frac{0.8^2}{0.8^2 + 0.2^2} = \frac{16}{17} \approx 0.941.$$

若第二个来源只是复制第一个来源，那么观察 $L_1 = L_2 = 1$ 只相当于一次报告，后验概率仍为 0.8。把复制误写成条件独立，会制造并不存在的证据增益。

在上述严格简化模型中，未知的 p 可以由多个对象上的无真值来源输出识别。事实上，两来源的一致率满足

$$a = \mathbb{P}(L_1 = L_2) = p^2 + (1 - p)^2.$$

该函数在 $p > 1/2$ 上严格递增，因此总体联合分布唯一确定

$$p = \frac{1 + \sqrt{2a - 1}}{2}.$$

有限样本只会带来对 a 和 p 的估计误差，不构成总体层面的不可识别性。

不可识别问题出现在更一般的来源模型中。例如，去掉 $p > 1/2$ 的方向约束会保留 p 与 $1 - p$ 的标签翻转；允许两个来源具有不同未知正确率时，一致率不足以分别确定两个参数；若进一步同时把类别先验和来源正确率设为未知，或允许未知的条件相关结构，不同参数组合也可能产生相同的来源联合分布。层次模型可以在多个对象间共享来源质量，但共享先验不会自动创造识别信息。只有在这类歧义确实存在时，才需要把锚点、已知质量来源、结构约束或少量可靠标签写进模型。更多来源也只有在其误差结构提供新增信息时才有帮助。

20.8.2 从人工规则、模型输出到学习目标

规则来源改变了表示方式。命题逻辑与约束可以排除不允许的答案，软约束则把违反程度加入优化目标。第 13 章提供有限约束、计数和求解边界，第 3 章说明惩罚、拉格朗日乘子和可行性。惩罚系数有限时，软约束通常不等于严格满足规则；规则之间冲突时，也必须规定优先级、松弛方式或不可行处理。

已有模型作为来源时，概率评分与校准评价其输出和实际频率之间的关系。一个模型报告 0.9，只表示它给出的概率数值，不表示该来源有 90% 的真实性。数据自身提供的增强视图、邻域或对比关系也属于来源假设：第 7 章可检查变换关系，第 11 章可比较分布与表示，但“哪些变化不改变任务语义”仍需由任务定义或证据支持。

示例 20.14 同一对象上的三种监督 设模型对对象 x_1 给出的正类概率为 $p_1 = 0.4$ ，对相邻对象 x_2 给出 $p_2 = 0.7$ ，并以 $\hat{y}_i = \mathbb{I}\{p_i \geq 1/2\}$ 形成类别决策。人工规则若断言“ x_1 必须属于正类”，可以把 $\hat{y}_1 = 1$ 写

成硬约束；当前决策不在可行集合中。若把规则改成有限权重的违反代价，模型就可以用其他目标收益抵消违规，不再具有同样的逻辑含义。

已有模型若为 $\mathbf{x}_1$ 提供软标签 $q_1 = 0.8$ ，概率监督可以加入交叉熵

$$-q_1 \log p_1 - (1 - q_1) \log(1 - p_1) \approx 0.835.$$

这个目标保留了来源报告的不确定程度，但 0.8 是否校准、是否代表来源正确率，仍需另行验证。若数据关系只说明 $\mathbf{x}_1$ 与 $\mathbf{x}_2$ 应有相同标签，一种关系监督是加入

$$(p_1 - p_2)^2 = 0.09.$$

它约束两个输出的一致性，却没有单独说明二者应接近 0 还是 1。三种信号作用于同一对象，但分别提供可行性、目标分布和对象间关系；数值 0.835 与 0.09 还受损失尺度和权重影响，不能直接当作监督强弱排序。

20.8.3 从被动接收信息到主动查询

主动查询把固定观测改成按历史选择信息。若当前信息为 $\mathcal{F}_t$ ，查询 q 产生观测 O_q ，一个简化的信息价值可写为

$$\text{VOI}(q) = \inf_a \mathbb{E}[\ell(a, Y) | \mathcal{F}_t] - \mathbb{E} \left[\inf_a \mathbb{E}[\ell(a, Y) | \mathcal{F}_t, O_q] \middle| \mathcal{F}_t \right].$$

它衡量查询后重新决策能减少多少条件风险。只要查询后允许忽略 O_q 并沿用原行动，且上述条件期望存在，第二项的最优风险不会高于第一项，因而 $\text{VOI}(q) \geq 0$ ；若行动集合或损失也随查询改变，就不能直接沿用这个比较。查询成本为 $c(q)$ 时，只有价值与成本的比较才决定是否查询。第 17 章提供信息价值，第 9 章提供自适应取样后的误差工具。

本节推导建立在来源正确率已定义、条件独立结构正确以及先验可用的条件下。实际知识获取还会遇到选择性缺失、来源共谋、任务漂移与反馈影响。后续知识获取部分会定义人工、规则、模型和数据来源各自的语义及质量标准；数学准备只能说明一条信息怎样进入后验、约束或决策，不能代替判断它是否真代表任务所需知识。

20.9 知识的演进与迁移

20.9.1 从输入分布变化到风险重加权

把已有模型用于新环境时，核心问题不是两个参数是否接近，而是目标环境中的风险能否由已有数据识别和估计。输入分布变化提供了一个最小例子：若条件标签规律保持，并且目标分布没有把质量放到来源从未覆盖的区域，来源样本可以通过密度比重加权目标平均。

设来源联合分布与目标联合分布分别为 P_s 和 P_t ，并假设

$$P_t(Y | X) = P_s(Y | X).$$

若目标输入分布相对于来源输入分布绝对连续，密度比

$$w(x) = \frac{dP_t^X}{dP_s^X}(x)$$

在来源几乎处处有定义。对可积损失，

$$\begin{aligned} R_t(h) &= \mathbb{E}_{P_t}[\ell(h(X), Y)] \\ &= \mathbb{E}_{P_s}[w(X)\ell(h(X), Y)]. \end{aligned} \quad (20.17)$$

第 8 章的换测度说明等式为何成立，第 11 章的分布差异则可进一步控制目标变化的大小。

示例 20.15 两点空间上的重加权 令 $X \in \{a, b\}$,

$$P_s^X(a) = \frac{3}{4}, \quad P_s^X(b) = \frac{1}{4}, \quad P_t^X(a) = P_t^X(b) = \frac{1}{2}.$$

密度比分别为 $w(a) = 2/3$ 和 $w(b) = 2$ 。若某预测规则在 a, b 处的条件期望损失分别为 0.1, 0.5，则来源平均风险为

$$\frac{3}{4}(0.1) + \frac{1}{4}(0.5) = 0.2,$$

而重加权来源风险为

$$\frac{3}{4} \frac{2}{3}(0.1) + \frac{1}{4} 2(0.5) = 0.3,$$

恰好等于目标平均风险 $\frac{1}{2}(0.1) + \frac{1}{2}(0.5)$ 。

重加权等式并不保证估计容易。若 $w(X)$ 很大，加权损失的方差可能很高；若目标在某区域有正概率而来源概率为零，绝对连续性失败，式 (20.17) 便不能从来源数据恢复该区域的目标风险。第 12 章的部分识别思路可以在额外边界假设下给出范围，但不能产生点识别。若 $P(Y | X)$ 本身改变，协变量偏移假设也已经失效。

20.9.2 从表示对应到多任务共享与适应

参数或表示迁移还需要定义“对应”。两个模型的参数可以因坐标变换、节点置换或低秩分解的不唯一性而数值不同，却表示同一个函数；参数接近也可能在病态方向上产生很大预测差异。第6章的扰动与低秩工具、第7章的坐标与对称性帮助建立可比较对象，但任务风险仍是最终要核对的量。

示例 20.16 同一映射的两组坐标表达 令 $T : \mathbb{R}^2 \rightarrow \mathbb{R}^2$ 在标准基 $\mathcal{B} = (\mathbf{e}_1, \mathbf{e}_2)$ 下的矩阵为

$$\mathbf{A}_{\mathcal{B}} = \begin{bmatrix} 2 & 0 \\ 0 & 1 \end{bmatrix}.$$

改用基 $\mathcal{C} = (\mathbf{c}_1, \mathbf{c}_2)$ ，其中 $\mathbf{c}_1 = \mathbf{e}_1 + \mathbf{e}_2$ 、 $\mathbf{c}_2 = \mathbf{e}_2$ 。从 $\mathcal{B}$ 坐标变到 $\mathcal{C}$ 坐标的矩阵及其逆为

$$\mathbf{S}_{\mathcal{C} \leftarrow \mathcal{B}} = \begin{bmatrix} 1 & 0 \\ -1 & 1 \end{bmatrix}, \quad \mathbf{S}_{\mathcal{B} \leftarrow \mathcal{C}} = \begin{bmatrix} 1 & 0 \\ 1 & 1 \end{bmatrix}.$$

第5章的换基公式给出

$$\mathbf{A}_{\mathcal{C}} = \mathbf{S}_{\mathcal{C} \leftarrow \mathcal{B}} \mathbf{A}_{\mathcal{B}} \mathbf{S}_{\mathcal{B} \leftarrow \mathcal{C}} = \begin{bmatrix} 2 & 0 \\ -1 & 1 \end{bmatrix}.$$

两个矩阵元素不同，却表示同一个 T 。例如 $\mathbf{v} = \mathbf{c}_1 = (1, 1)^\top$ 满足

$$[\mathbf{v}]_{\mathcal{B}} = \begin{bmatrix} 1 \\ 1 \end{bmatrix}, \quad [\mathbf{v}]_{\mathcal{C}} = \begin{bmatrix} 1 \\ 0 \end{bmatrix}.$$

在标准坐标中 $T(\mathbf{v}) = (2, 1)^\top$ ；在 $\mathcal{C}$ 坐标中，

$$\mathbf{A}_{\mathcal{C}}[\mathbf{v}]_{\mathcal{C}} = \begin{bmatrix} 2 \\ -1 \end{bmatrix} = [T(\mathbf{v})]_{\mathcal{C}},$$

而 $2\mathbf{c}_1 - \mathbf{c}_2 = (2, 1)^\top$ 。因此比较迁移前后的参数数组之前，必须先说明坐标或对称代表怎样对应；矩阵数值不相同本身不表示函数关系改变。

多个任务共享信息时，可以用层次模型让任务参数围绕共同结构变化，也可以用低秩矩阵限制任务间自由度。共享越强，数据少的任务可能获得更低方差，但真实任务差异若超出共享结构，也会引入偏差。多目标优化说明任务梯度冲突时不存在同时改善所有目标的无条件更新，双层优化与隐式求导则组织“用一组数据选择适应规则、用另一组数据评价”的依赖。这些数学形式需要后续章节明确任务抽样和数据划分。

20.9.3 从固定任务更新到变化跟踪与能力保留

持续学习还增加时间轴。若环境在时刻 t 的最优参数为 θ_t^* ，一个简单的跟踪误差分解可写成

$$\|\theta^{(t+1)} - \theta_{t+1}^*\|_2 \leq \|\theta^{(t+1)} - \theta_t^*\|_2 + \|\theta_t^* - \theta_{t+1}^*\|_2.$$

第一项反映在当前目标上的更新误差，第二项反映环境本身的漂移。固定平均动力学下的收敛结论只控制第一类行为；若第二项长期不小，算法最多讨论跟踪范围，而不能声称收敛到固定点。

旧能力保留与新环境适应也不是同一个指标。保留需要指定哪些旧任务、输出或行为不得退化，适应则需要指定新任务上的收益；定向修正还要规定哪些内容允许改变。第10章的时间抽样、重采样和选择后证据支持持续评价，但反复按结果调整测试集会削弱证据。

后续知识演进与迁移部分将讨论复用判断、持续更新、模型整合、多任务共享和快速适应。本节的密度比推导只覆盖条件规律保持且支持充分的输入分布变化；低秩、参数距离或表示对齐只提供结构线索。能否从旧经验获得目标任务收益，仍取决于任务关系、数据覆盖和评价协议。

20.10 本章小结

本章回答的问题是：已经掌握的数学怎样进入后续机器学习研究。关键不是按方法名称查找公式，而是确定结论控制的对象。学习理论中的同时误差连接数据依赖选择与总体风险；投影、谱和核连接表示结构与拟合及数值条件；群作用、卷积和状态递推连接输入结构与函数族；链式法则、曲率与随机逼近分别控制导数、单步更新和长期迭代。

概率模型进一步表明，同一个联合分布上的推断、参数学习和生成具有不同输入输出。可信性要求把总体覆盖、条件覆盖、扰动鲁棒、因果目标和隐私保护分别定义。强化学习把行动引入数据生成过程，因此规划固定点、随机更新、探索证据、离线支持和安全约束不能相互替代。知识获取关心来源是否提供独立且可识别的信息，知识迁移则关心目标风险是否能由来源分布和共享结构支持。

这些方向反复使用前述工具，也不断改变其成立条件。空间结构组织表示，微分与优化组织求解，概率与统计组织证据，离散结构组织关系与计算，动态、控制和博弈组织行动后果。推导成立要求数学假设与观测制度、数据分布、候选空间和可用计算相匹配；公式外形相似不能代替核对。

后续各卷将补充模型、算法、数据协议和专门保证。应用研究需定义任务输出，系统研究需纳入有限精度、资源预算、并发和部署约束。数学准备能区分误差来源；只有对象与条件完整，工具才能形成可检验的结论。



参考文献

- C. C. Aggarwal, *Recommender Systems*, Springer, 2016.
- S.-i. Amari, *Natural Gradient Works Efficiently in Learning* In Neural Computation, 1998, vol. 10, no. 2, pp. 251–276.
- A. D. Ames, X. Xu, J. W. Grizzle, P. Tabuada, *Control Barrier Function Based Quadratic Programs for Safety Critical Systems* In IEEE Transactions on Automatic Control, 2017, vol. 62, no. 8, pp. 3861–3876.
- B. D. O. Anderson, J. B. Moore, *Optimal Control: Linear Quadratic Methods*, Dover Publications, 2007.
- N. Aronszajn, *Theory of Reproducing Kernels* In Transactions of the American Mathematical Society, 1950, vol. 68, no. 3, pp. 337–404.
- S. Axler, *Linear Algebra Done Right*, Springer, 2015, 3rd ed.
- M. Bardi, I. Capuzzo-Dolcetta, *Optimal Control and Viscosity Solutions of Hamilton–Jacobi–Bellman Equations*, Birkhäuser, 1997.
- C. M. Bishop, *Pattern Recognition and Machine Learning*, Springer, 2006, 1st ed.
- C. M. Bishop, H. Bishop, *Deep Learning: Foundations and Concepts*, Springer, 2024.
- V. S. Borkar, *Stochastic Approximation: A Dynamical Systems Viewpoint*, Cambridge University Press, 2008.
- S. Boyd, L. Vandenberghe, *Convex Optimization*, Cambridge University Press, 2004.
- F. R. K. Chung, *Spectral Graph Theory*, American Mathematical Society, 1997, 1st ed.
- J. B. Conway, *A Course in Functional Analysis*, Springer, 1990, 2nd ed.
- S. A. Cook, *The Complexity of Theorem-Proving Procedures* In Proceedings of the Third Annual ACM Symposium on Theory of Computing, 1971, pp. 151–158.
- J. W. Cooley, J. W. Tukey, *An Algorithm for the Machine Calculation of Complex Fourier Series* In Mathematics of Computation, 1965, vol. 19, no. 90, pp. 297–301.

- T. H. Cormen, C. E. Leiserson, R. L. Rivest, C. Stein, *Introduction to Algorithms*, MIT Press, 2022, 4th ed.
- T. M. Cover, J. A. Thomas, *Elements of Information Theory*, Wiley, 2006, 2nd ed.
- M. P. Deisenroth, A. A. Faisal, C. S. Ong, *Mathematics for Machine Learning*, Cambridge University Press, 2020.
- R. Diestel, *Graph Theory*, Springer, 2017, 5th ed.
- C. Eckart, G. Young, *The Approximation of One Matrix by Another of Lower Rank* In *Psychometrika*, 1936, vol. 1, no. 3, pp. 211–218.
- G. B. Folland, *Real Analysis: Modern Techniques and Their Applications*, Wiley, 1999, 2nd ed.
- A. Géron, *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow*, O'Reilly Media, 2022, 3rd ed.
- G. H. Golub, C. F. Van Loan, *Matrix Computations*, Johns Hopkins University Press, 2013, 4th ed.
- I. Goodfellow, Y. Bengio, A. Courville, *Deep Learning*, MIT Press, 2016.
- R. L. Graham, D. E. Knuth, O. Patashnik, *Concrete Mathematics: A Foundation for Computer Science*, Addison-Wesley, 1994, 2nd ed.
- E. Hairer, S. P. Nørsett, G. Wanner, *Solving Ordinary Differential Equations I: Nonstiff Problems*, Springer, 1993, 2nd ed.
- T. Hastie, R. Tibshirani, J. Friedman, *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*, Springer, 2009, 2nd ed.
- M. A. Hernán, J. M. Robins, *Causal Inference: What If*, Chapman & Hall/CRC, 2020.
- R. A. Horn, C. R. Johnson, *Matrix Analysis*, Cambridge University Press, 2013, 2nd ed.
- C. Huyen, *Designing Machine Learning Systems*, O'Reilly Media, 2022.
- G. James, D. Witten, T. Hastie, R. Tibshirani, *An Introduction to Statistical Learning*, Springer, 2021, 2nd ed.
- D. Jurafsky, J. H. Martin, *Speech and Language Processing*, Prentice Hall, 2009, 2nd ed.
- S. Kakutani, *A Generalization of Brouwer's Fixed Point Theorem* In *Duke Mathematical Journal*, 1941, vol. 8, no. 3, pp. 457–459.
- O. Kallenberg, *Foundations of Modern Probability*, Springer, 2021, 3rd ed.
- R. E. Kalman, *A New Approach to Linear Filtering and Prediction Problems* In *Journal of Basic Engineering*, 1960, vol. 82, no. 1, pp. 35–45.
- H. K. Khalil, *Nonlinear Systems*, Prentice Hall, 2002, 3rd ed.
- M. Kleppmann, C. Riccomini, *Designing Data-Intensive Applications*, O'Reilly Media, 2026, 2nd ed.

- D. E. Knuth, *The Art of Computer Programming, Volume 2: Seminumerical Algorithms*, Addison-Wesley, 1997, 3rd ed.
- D. Koller, N. Friedman, *Probabilistic Graphical Models: Principles and Techniques*, MIT Press, 2009.
- V. Kolmogorov, R. Zabih, *What Energy Functions Can Be Minimized via Graph Cuts?* In *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2004, vol. 26, no. 2, pp. 147–159.
- J. M. Lee, *Introduction to Smooth Manifolds*, Springer, 2013, 2nd ed.
- E. L. Lehmann, J. P. Romano, *Testing Statistical Hypotheses*, Springer, 2005, 3rd ed.
- M. Leshno, V. Y. Lin, A. Pinkus, S. Schocken, *Multilayer Feedforward Networks with a Nonpolynomial Activation Function Can Approximate Any Function* In *Neural Networks*, 1993, vol. 6, no. 6, pp. 861–867.
- C. D. Manning, P. Raghavan, H. Schütze, *Introduction to Information Retrieval*, Cambridge University Press, 2008.
- J. Mercer, *Functions of Positive and Negative Type, and Their Connection with the Theory of Integral Equations* In *Philosophical Transactions of the Royal Society of London, Series A*, 1909, vol. 209, pp. 415–446.
- S. P. Meyn, R. L. Tweedie, *Markov Chains and Stochastic Stability*, Cambridge University Press, 2009, 2nd ed.
- T. M. Mitchell, *Machine Learning*, McGraw-Hill, 1997, 1st ed.
- M. Mohri, A. Rostamizadeh, A. Talwalkar, *Foundations of Machine Learning*, The MIT Press, 2018, 2nd ed.
- K. P. Murphy, *Machine Learning: A Probabilistic Perspective*, MIT Press, 2012.
- K. P. Murphy, *Probabilistic Machine Learning*, The MIT Press, 2023.
- K. P. Murphy, *Probabilistic Machine Learning: An Introduction*, MIT Press, 2022.
- J. Nash, *Non-Cooperative Games* In *The Annals of Mathematics*, 1951, vol. 54, no. 2, pp. 286–295.
- G. L. Nemhauser, L. A. Wolsey, M. L. Fisher, *An Analysis of Approximations for Maximizing Submodular Set Functions—I* In *Mathematical Programming*, 1978, vol. 14, pp. 265–294.
- J. Nocedal, S. J. Wright, *Numerical Optimization*, Springer, 2006, 2nd ed.
- B. Øksendal, *Stochastic Differential Equations: An Introduction with Applications*, Springer, 2003, 6th ed.
- J. Pearl, *Causality: Models, Reasoning, and Inference*, Cambridge University Press, 2009, 2nd ed.
- J. Pearl, *Probabilistic Reasoning in Intelligent Systems: Networks of Plausible Inference*, Morgan Kaufmann, 1988.

- M. L. Puterman, *Markov Decision Processes: Discrete Stochastic Dynamic Programming*, Wiley, 1994.
- C. E. Rasmussen, C. K. I. Williams, *Gaussian Processes for Machine Learning*, MIT Press, 2006.
- H. E. Rauch, F. Tung, C. T. Striebel, *Maximum Likelihood Estimates of Linear Dynamic Systems* In *AIAA Journal*, 1965, vol. 3, no. 8, pp. 1445–1450.
- H. Robbins, S. Monro, *A Stochastic Approximation Method* In *The Annals of Mathematical Statistics*, 1951, vol. 22, no. 3, pp. 400–407.
- R. T. Rockafellar, S. Uryasev, *Optimization of Conditional Value-at-Risk* In *The Journal of Risk*, 2000, vol. 2, no. 3, pp. 21–41.
- A. Ruszczyński, *Risk-Averse Dynamic Programming for Markov Decision Processes* In *Mathematical Programming*, 2010, vol. 125, no. 2, pp. 235–261.
- B. Schölkopf, R. Herbrich, A. J. Smola, *A Generalized Representer Theorem* In *Computational Learning Theory*, 2001, pp. 416–426.
- S. Shalev-Shwartz, S. Ben-David, *Understanding Machine Learning: From Theory to Algorithms*, Cambridge University Press, 2014, 1st ed.
- L. S. Shapley, “A Value for n -Person Games”, in: *Contributions to the Theory of Games II*, ed. by H. W. Kuhn, A. W. Tucker, vol. 28, *Annals of Mathematics Studies*, Princeton University Press, 1953, pp. 307–318.
- R. S. Sutton, A. G. Barto, *Reinforcement Learning: An Introduction*, MIT Press, 2018, 2nd ed.
- R. Szeliski, *Computer Vision*, Springer, 2022, 2nd ed.
- C. Szepesvári, *Algorithms for Reinforcement Learning*, Morgan & Claypool Publishers, 2010.
- A. M. Turing, *On Computable Numbers, with an Application to the Entscheidungsproblem* In *Proceedings of the London Mathematical Society*, 1937, vol. 42, no. 1, pp. 230–265.
- A. W. van der Vaart, *Asymptotic Statistics*, Cambridge University Press, 1998.
- C. Villani, *Optimal Transport: Old and New*, Springer, 2009.
- S. Winograd, *Arithmetic Complexity of Computations*, Society for Industrial and Applied Mathematics, 1980.
- A. Zhang, Z. C. Lipton, M. Li, A. J. Smola, *Dive into Deep Learning*, Cambridge University Press, 2023.
- M. Zinkevich, *Online Convex Programming and Generalized Infinitesimal Gradient Ascent* In *Proceedings of the Twentieth International Conference on Machine Learning*, 2003, pp. 928–936.
- M. Zinkevich, M. Johanson, M. Bowling, C. Piccione, *Regret Minimization in Games with Incomplete Information* In *Advances in Neural Information Processing Systems*, 2007, pp. 1729–1736.

周志华, 机器学习, 清华大学出版社, 2016, 1st ed.

李航, 统计学习方法, 清华大学出版社, 2019, 2nd ed.

邱锡鹏, 神经网络与深度学习, 机械工业出版社, 2020.

索引

- 3-SAT, 324
- μ 强凸, μ -strongly convex, 51
- 一致, consistent, 242
- 一致可积, uniformly integrable, 197
- 一致性, consistency, 300
- 一致紧的, uniformly tight, 283
- 一致连续, uniformly continuous, 19
- 一阶可行方向, linearized feasible direction, 59
- 三角不等式, triangle inequality, 109
- 上半连续, upper hemicontinuous, 487
- 上确界, supremum, 13
- 下半连续, lower semicontinuous, 49
- 下确界, infimum, 12
- 下采样, downsampling, 387
- 不变, invariant, 163
- 不变集, invariant set, 406
- 不可约性, irreducibility, 216
- 不可行, infeasible, 48
- 中介变量, mediator, 297
- 中值定理, mean value theorem, 22
- 主动学习, active learning, 263
- 主化-最小化方法, majorization-minimization, 70
- 主成分分析, principal component analysis, 128
- 主角, principal angles, 140
- 乘积测度, product measure, 30
- 二元关系, binary relation, 3
- 二部图, bipartite graph, 338
- 二项分布, binomial distribution, 187
- 互信息, mutual information, 267
- 互相关, cross-correlation, 370
- 交叉熵, cross-entropy, 270
- 交叉验证, cross-validation, 253
- 交替最小化, alternating minimization, 69
- σ 代数, sigma-algebra, 27
- 仿射包, affine hull, 64
- 优化问题, optimization problem, 331
- 伪多项式时间算法, pseudo-polynomial-time algorithm, 334
- 伪真参数, pseudo-true parameter, 240
- 伪距离, pseudometric, 112
- 估计值, estimate, 236
- 估计误差, estimation error, 511
- 估计量, estimator, 235
- 似然, likelihood, 238
- 信念状态, belief state, 478
- 信息集, information set, 492
- 熵, entropy, 266
- 牛顿法, Newton's method, 57
- 特征值, eigenvalue, 121
- 特征向量, eigenvector, 121
- 状态转移矩阵, state transition matrix, 397
- 独立, independent, 185
- 环, cycle, 338
- 生成树, spanning tree, 353
- 目标总体, target population, 237
- 相关均衡, correlated equilibrium, 490
- 相对内部, relative interior, 64
- 相对熵, relative entropy, 270
- 相对阶, relative degree, 472
- 相干风险, coherent risk measure, 436
- 矩形性, rectangularity, 453
- 矩母函数, moment-generating function, 185
- 矩阵博弈, matrix game, 480
- 矩阵范数, matrix norm, 130
- 硬约束, hard constraint, 326
- 碰撞点, collider, 297, 298
- 祖先, ancestor, 298
- 离散代数 Riccati 方程, discrete algebraic Riccati equation, 464
- 离散傅里叶变换, discrete Fourier transform, 375
- 离散卷积, discrete convolution, 370
- 离散时间信号, discrete-time signal, 368

- 离散时间傅里叶变换, discrete-time Fourier transform, 386
- 秩, rank, 106
- 积分概率度量, integral probability metric, 275
- 稳定, stable, 402
- 稳定化解, stabilizing solution, 464
- 稳定秩, stable rank, 131
- 笛卡尔积, Cartesian product, 3
- 等价关系, equivalence relation, 3
- 等价类, equivalence class, 3
- 等变, equivariant, 163
- 等变性, equivariance, 515
- 简单函数, simple function, 28
- 算法稳定性, algorithmic stability, 69
- 粗相关均衡, coarse correlated equilibrium, 490
- 紧的, tight, 283
- 紧致, compact, 20
- 累积量生成函数, cumulant-generating function, 185
- 约束资格条件, constraint qualification, 59
- 纯策略, pure strategy, 480
- 线性二次调节, linear-quadratic regulation, 462
- 线性子空间, linear subspace, 101
- 线性无关, linearly independent, 102
- 线性映射, linear map, 103
- 线性组合, linear combination, 101
- 线性表示, linear representation, 162
- 组合图拉普拉斯, combinatorial graph Laplacian, 358
- 细致平衡, detailed balance, 216
- 结构因果模型, structural causal model, 295
- 绝对可积, absolutely integrable, 30
- 绝对收敛, absolutely converge, 18
- 绝对连续, absolutely continuous, 43, 175
- 绝对连续曲线, absolutely continuous curve, 395
- 统计模型, statistical model, 235
- 统计量, statistic, 235
- 维度重排, permutation of axes, 115
- 维数, dimension, 102
- 置信区间, confidence interval, 246, 309
- 置信序列, confidence sequence, 223, 255
- 置换检验, permutation test, 253
- 群, group, 162
- 群作用, group action, 162
- 耦合, coupling, 283
- 联合可利用度, joint exploitability, 502
- 联络, connection, 156
- 胖打散维, fat-shattering dimension, 94
- 脉冲响应, impulse response, 369
- 自归一化, self-normalized, 224
- 自然梯度, natural gradient, 288
- 自相关有效样本量, autocorrelation effective sample size, 218
- 范数, norm, 108
- 范畴, category, 168
- 蕴含, implication, 8
- 虚设参与者性质, dummy player property, 504
- 行为策略, behavior strategy, 492
- 行列式, determinant, 105
- 行动补救, algorithmic recourse, 311
- 行空间, row space, 106
- 覆盖率, coverage, 434
- 覆盖边, covered edge, 313
- 证书, certificate, 333
- 证据下界, evidence lower bound, 290
- 评价 σ 代数, evaluation sigma-algebra, 193
- 评分规则, scoring rule, 255
- 识别集合, identified set, 305
- 诱导子图, induced subgraph, 343
- 诱导宽度, induced width, 343
- 诱导的算子范数, induced operator norm, 37
- 谱范数, spectral norm, 126
- 赋值, assignment, 323
- 赋范空间, normed space, 76
- 超图, hypergraph, 338
- 路径, path, 297, 338
- 转置, transpose, 104
- 辛形式, symplectic form, 427
- 边界, boundary, 166
- 边际覆盖, marginal coverage, 212
- 近似最优解, approximately optimal solution, 13
- 近共线, nearly collinear, 100
- 连续, continuous, 19
- 连续 S 形函数, continuous sigmoidal function, 89
- 连通, connected, 338
- 迭代法, iterative method, 144
- 迹, trace, 116
- 迹类算子, trace-class operator, 93
- 适当, proper, 255
- 选择性预测, selective prediction, 434
- 逐元素乘积, Hadamard product, 116
- 递推, recurrence, 6
- 逻辑后承, logical consequence, 325
- 逼近误差, approximation error, 511
- 遗憾匹配, regret matching, 497
- 邻域, neighborhood, 337

- 邻接矩阵, adjacency matrix, 339
- 邻近算子, proximal operator, 66
- 部分识别, partial identification, 305
- 链式法则, chain rule, 23
- 锐度, sharpness, 256
- 锐界, sharp bounds, 306
- 错误发现率, false discovery rate, 254
- 长度最短测地线, length-minimizing geodesic, 158
- 闭链, cycle, 166
- 闭集, closed set, 19
- 随机化检验函数, randomized test function, 249
- 随机变量, random variable, 173
- 随机向量, random vector, 191
- 随机干预, stochastic intervention, 296
- 随机缺失, missing at random, 259
- 隐式超梯度, implicit hypergradient, 74
- 集合, set, 2
- 集合值映射, correspondence, 487
- 集合族, set family, 318
- 零可控性, null controllability, 457
- 零和博弈, zero-sum game, 480
- 零测集, null set, 28
- 零空间, null space, 106
- 零阶保持, zero-order hold, 401
- 非周期的, aperiodic, 216
- 非随机缺失, missing not at random, 259
- 鞅, martingale, 220
- 鞅差, martingale difference, 220
- 鞍点, saddle point, 27
- 预条件, preconditioning, 58, 144
- 预测集合, prediction set, 246
- 频率响应, frequency response, 387
- 风险, risk, 241
- 风险价值, value at risk, 436
- 驻点, stationary point, 48
- 骨架, skeleton, 313
- 高斯分布, Gaussian distribution, 188
- 黏性解, viscosity solution, 477
- Banach 空间, Banach space, 77
- Bayes 决策规则, Bayes decision rule, 432
- Bayes 因子, Bayes factor, 260
- Bayes 行动, Bayes action, 432
- Bernoulli 分布, Bernoulli distribution, 187
- Beta 分布, Beta distribution, 189
- Bootstrap, 252
- Borel σ 代数, Borel sigma-algebra, 27
- Cayley–Hamilton 定理, Cayley–Hamilton theorem, 121
- Čech 复形, Čech complex, 165
- Chapman–Kolmogorov 关系, Chapman–Kolmogorov relation, 215
- Clarke 广义梯度, Clarke generalized gradient, 40
- Dirichlet 分布, Dirichlet distribution, 189
- Dirichlet 能量, Dirichlet energy, 159
- Dirichlet 过程, Dirichlet process, 193
- d-分离, d-separated, 298
- Fisher 信息, Fisher information, 244
- Fisher 信息矩阵, Fisher information matrix, 286
- Fisher 度量, Fisher metric, 287
- Fokker–Planck 方程, Fokker–Planck equation, 424
- Fréchet 导数, Fréchet derivative, 136
- Gamma 分布, Gamma distribution, 188
- Gauss–Newton 法, Gauss–Newton method, 57
- Gram 矩阵, Gram matrix, 114, 148
- Hamilton–Jacobi–Bellman 方程, Hamilton–Jacobi–Bellman equation, 474
- Harris 常返性, Harris recurrence, 218
- Hellinger 距离, Hellinger distance, 274
- Hessian 矩阵, Hessian matrix, 25
- Hilbert 空间, Hilbert space, 78
- Itô 等距, Itô isometry, 420
- Jacobian 矩阵, Jacobian matrix, 23
- Jensen 不等式, Jensen's inequality, 51
- Karush–Kuhn–Tucker 条件, Karush–Kuhn–Tucker conditions, 59
- KL 散度, Kullback–Leibler divergence, 255
- Kronecker 积, Kronecker product, 117
- Laplace–Beltrami 算子, Laplace–Beltrami operator, 160
- Levi–Civita 联络, Levi–Civita connection, 156
- Lipschitz 连续, Lipschitz continuous, 20
- Luenberger 观测器, Luenberger observer, 461
- L 光滑, L -smooth, 51
- Lyapunov 函数, Lyapunov function, 404

- Markov 决策过程, Markov decision process, 440
- Markov 等价, Markov equivalent, 313
- Markov 等价类, Markov equivalence class, 313
- Markov 链, Markov chain, 215
- Minkowski 不等式, Minkowski inequality, 77
- Möbius 反演, Möbius inversion, 321
- Moore–Penrose 伪逆, Moore–Penrose pseudoinverse, 128
- M 估计, M -estimation, 239

- Nash 协商解, Nash bargaining solution, 506
- Nash 均衡, Nash equilibrium, 485
- Nesterov 加速梯度, Nesterov accelerated gradient, 56
- NP 困难, NP-hard, 333
- NP 完全, NP-complete, 333

- ODE 方法, ODE method, 229

- Paley–Wiener 带限空间, Paley–Wiener bandlimited space, 384
- Pareto 最优, Pareto optimal, 71, 506
- Parseval 关系, Parseval relation, 376
- Poisson 分布, Poisson distribution, 188
- Poisson 方程, Poisson equation, 230
- Polyak–Łojasiewicz 条件, PL condition, 52
- p 值, p -value, 249

- q 分位数, quantile, 248

- Rademacher 复杂度, Rademacher complexity, 208
- Radon–Nikodym 导数, Radon–Nikodym derivative, 176
- Rayleigh 商, Rayleigh quotient, 123
- Rényi 散度, Rényi divergence, 275
- Riemann 度量, Riemannian metric, 154
- Riemann 梯度, Riemannian gradient, 159

- Schatten p 范数, Schatten p -norm, 130
- Schur 补, Schur complement, 134
- Shapley 值, Shapley value, 504
- Sylvester 方程, Sylvester equation, 137

- 假设检验, hypothesis testing, 249
- 偏导数, partial derivative, 21
- 偏序关系, partial order, 4
- 停时, stopping time, 220
- 傅里叶系数, Fourier coefficient, 377
- 充分统计量, sufficient statistic, 239
- 入度, in-degree, 337
- 全局最优解, global minimizer, 48
- 全局最小点, global minimizer, 12
- 全方差公式, law of total variance, 183
- 全期望公式, law of total expectation, 182
- 全称量词, universal quantifier, 8
- 共同下降方向, common descent direction, 71
- 共同原因, common cause, 296
- 共轭对称, conjugate symmetry, 376
- 共轭转置, conjugate transpose, 105, 375
- 关联矩阵, incidence matrix, 340
- 内积, inner product, 107
- 内积空间, inner-product space, 78
- 内部遗憾, internal regret, 495
- 再生核, reproducing kernel, 83
- 再生核 Hilbert 空间, reproducing kernel Hilbert space, 83
- 几乎处处, almost everywhere, 28
- 几何遍历性, geometric ergodicity, 219
- 凸函数, convex function, 50
- 凸松弛, convex relaxation, 65
- 凸集, convex set, 50
- 出度, out-degree, 337
- 函数, function, 4
- 分位数回归, quantile regression, 248
- 分块坐标法, block coordinate method, 69
- 分布, distribution, 173
- 分布鲁棒优化, distributionally robust optimization, 439
- 分离原则, separation principle, 468
- 分离原理, separation principle, 461
- 分隔, separate, 342
- 切空间, tangent space, 153
- 列空间, column space, 106
- 创新协方差, innovation covariance, 411
- 判定问题, decision problem, 331
- 到达概率, reach probability, 494
- 前向误差, forward error, 145
- 剩余类, residue class, 374
- 加权平均, weighted average, 6
- 加权重, weighted degree, 358
- 加权最小二乘, weighted least squares, 113
- 动量法, momentum, 56
- 包络定理, envelope theorem, 38
- 匹配, matching, 355
- 区分能力, discrimination, 256
- 半可判定的, semidecidable, 331
- 半正定锥, positive semidefinite cone, 52
- 半环, semiring, 347

- 协变导数, covariant derivative, 156
- 单射, injective, 4
- 单纯形, simplex, 165
- 单纯顶点, simplicial vertex, 343
- 单调性, monotonicity, 309, 328
- 占用度量, occupancy measure, 444
- 卡方分布, chi-square distribution, 207
- 卷积, convolution, 118
- 压缩映射, contraction mapping, 44
- 原像, preimage, 4
- 原始关系图, primal graph, 336
- 原始-对偶间隙, primal-dual gap, 72
- 双层优化, bilevel optimization, 73
- 双重中心化, double centering, 148
- 反事实, counterfactual, 309
- 反事实价值, counterfactual value, 494
- 反事实遗憾最小化, counterfactual regret minimization, 497
- 反馈, feedback, 455
- 可交换, exchangeable, 210
- 可信区间, credible interval, 246
- 可判定的, decidable, 331
- 可加性, additivity, 504
- 可微, differentiable, 22
- 可控 Gram 矩阵, controllability Gramian, 458
- 可枚举的, computably enumerable, 331
- 可测函数, measurable function, 28
- 可满足, satisfiable, 324
- 可计算函数, computable function, 331
- 可识别, identifiable, 301
- 可识别的, identifiable, 236
- 可转移效用合作博弈, transferable-utility cooperative game, 503
- 可预测二次变差, predictable quadratic variation, 220
- 可预测过程, predictable process, 219
- 合取范式, conjunctive normal form, 324
- 同构, isomorphic, 365
- 后代, descendant, 297
- 后向稳定, backward stability, 143
- 后向误差, backward error, 145
- 后门准则, back-door criterion, 303
- 后门路径, back-door path, 303
- 后验分布, posterior distribution, 245
- 向量场, vector field, 156
- 向量空间, vector space, 101
- 周期, period, 216
- 命题, proposition, 8
- 哑索引, dummy index, 6
- 因果 Markov 性, causal Markov condition, 299
- 团, clique, 342
- 图信号, graph signal, 389
- 图傅里叶变换, graph Fourier transform, 389
- 坐标, coordinates, 102
- 坐标图, chart, 152
- 坐标过渡, coordinate transition, 152
- 基, basis, 102
- 基带, baseband, 384
- 填充边, fill-in edge, 342
- 增广路径, augmenting path, 355
- 增长函数, growth function, 93
- 复共轭, complex conjugate, 374
- 复合, composition, 5
- 外部遗憾, external regret, 495
- 多元高斯随机向量, multivariate Gaussian random vector, 191
- 多方信用分配, multi-party credit allocation, 503
- 多重集合, multiset, 365
- 多项分布, multinomial distribution, 188
- 多项式插值, polynomial interpolation, 373
- 多项式时间多对一归约, polynomial-time many-one reduction, 333
- 奇异值分解, singular value decomposition, 125
- Ville 不等式, Ville's inequality, 223
- 存在量词, existential quantifier, 8
- 完全信息价值, expected value of perfect information, 446
- 完全回忆, perfect recall, 492
- 完全图, complete graph, 343
- 完全随机缺失, missing completely at random, 259
- 完备, complete, 43
- 完备性, completeness, 17
- 完备正交系, complete orthonormal system, 81
- 完美消元序, perfect elimination ordering, 343
- 容斥原理, inclusion-exclusion principle, 320
- 对偶函数, dual function, 61
- 对偶范数, dual norm, 110
- 对数损失, log loss, 270
- 对称归一化拉普拉斯, symmetric normalized Laplacian, 359
- 对称性, symmetry, 504
- 导数, derivative, 21
- 局部 Lipschitz 函数, locally Lipschitz function, 40
- 局部最优解, local minimizer, 48
- 嵌套动态风险, nested dynamic risk, 450
- 布尔公式, Boolean formula, 323
- 布尔可满足性问题, Boolean satisfiability problem, 324

- 常返状态, recurrent state, 216
- 幂集, power set, 3
- 干预, intervention, 296
- 平均处理效应, average treatment effect, 299
- 平移不变性, translation invariance, 369
- 平稳分布, stationary distribution, 215
- 平稳过程, stationary process, 215
- 平行四边形恒等式, parallelogram identity, 79
- 广义特征值问题, generalized eigenvalue problem, 124
- 广度优先搜索, breadth-first search, 341
- 序列紧致性, sequential compactness, 20
- 度, degree, 337
- 度量, metric, 19
- 度量空间, metric space, 19
- 开环控制, open-loop control, 456
- 开覆盖, open cover, 20
- 开集, open set, 19
- 张成空间, span, 101
- 张量, tensor, 115
- 张量缩并, tensor contraction, 115
- 弦图, chordal graph, 343
- 弯曲点带, curved point band, 147
- ρ 弱凸, ρ -weakly convex, 52
- 弱对偶, weak duality, 61
- 弱导数, weak derivative, 90
- 弱连通, weakly connected, 339
- 强制的, coercive, 49
- 强解, strong solution, 421
- 强连通, strongly connected, 339
- 归一化割, normalized cut, 361
- 归一化指数映射, softmax, 24
- 形状重整, reshape, 115
- 影响函数, influence function, 241
- 循环卷积, circular convolution, 371
- 微分熵, differential entropy, 269
- 忠实性, fidelity, 313
- 快速傅里叶变换, fast Fourier transform, 378
- 总变差距离, total variation distance, 217, 273
- 战略式博弈, strategic-form game, 485
- 截断分解, truncated factorization, 296
- 扩展式博弈, extensive-form game, 491
- 投影, projection, 66
- 抗混叠滤波, anti-aliasing filtering, 387
- 抽样制度, sampling regime, 237
- 抽象单纯复形, abstract simplicial complex, 165
- 拉格朗日函数, Lagrangian, 59
- 拓扑, topology, 165
- 拟牛顿法, quasi-Newton method, 57
- 指数分布, exponential distribution, 188
- 指数族, exponential family, 190
- 探索, exploration, 448
- 搜索问题, search problem, 331
- 支持重叠, overlap, 302
- 支撑超平面, supporting hyperplane, 52
- 支配, dominate, 71
- 收敛, converge, 16
- 散度定理, divergence theorem, 33
- 数列, sequence, 16
- 数理统计, mathematical statistics, 235
- 整数间隙, integrality gap, 330
- 方向导数, directional derivative, 21
- 族错误率, family-wise error rate, 254
- 无下界, unbounded below, 48
- 无向图, undirected graph, 337
- 无屏蔽碰撞结构, unshielded collider, 313
- 无环, acyclic, 295
- 无穷级数, infinite series, 18
- 时间一致性, time consistency, 450
- 时间齐次的, time-homogeneous, 215
- 替代梯度, surrogate gradient, 40
- 最优传输, optimal transport, 283
- 最佳响应, best response, 481
- 最大公因式, greatest common divisor, 373
- 最大均值差异, maximum mean discrepancy, 275
- 最大熵原理, maximum entropy principle, 272
- 最小二乘, least squares, 113
- 最小描述长度, minimum description length, 262
- 最小生成树, minimum spanning tree, 353
- 有向图, directed graph, 337
- 有向无环图, directed acyclic graph, 339
- 有向环, directed cycle, 339
- 有向路径, directed path, 297
- 有效定义域, effective domain, 64
- 有效性, efficiency, 504
- 有效秩, effective rank, 131
- 有效维度, effective dimension, 92
- 有限子覆盖, finite subcover, 20
- 期望样本信息价值, expected value of sample information, 446
- 本质上确界, essential supremum, 42
- 机会约束, chance constraint, 438
- 权重, weight, 337

- 条件互信息, conditional mutual information, 268
- 条件交换性, conditional exchangeability, 302
- 条件数, condition number, 138
- 条件期望, conditional expectation, 180
- 条件熵, conditional entropy, 267
- 条件风险, conditional risk, 431
- 条件风险价值, conditional value at risk, 437
- 条件风险映射, conditional risk mapping, 449
- 极分解, polar decomposition, 136
- 极小极大鞍点, minimax saddle point, 72
- ω 极限集, ω -limit set, 406
- 查询树, query tree, 96
- 柯西数列, Cauchy sequence, 17
- 标准 Borel 空间, standard Borel space, 179
- 树, tree, 338
- 树分解, tree decomposition, 344
- 树宽, treewidth, 345
- 校准, calibration, 256
- 核心, core, 506
- 梯度, gradient, 22
- 概率有界, bounded in probability, 242
- 概率核, probability kernel, 179
- 概率空间, probability space, 172
- 模型, model, 323
- 次梯度, subgradient, 66
- 次模函数, submodular function, 327
- 次高斯变量, sub-Gaussian random variable, 203
- 正 Harris 常返性, positive Harris recurrence, 218
- 正交, orthogonal, 108
- 正交投影, orthogonal projection, 112
- 正值性, positivity, 302
- 正则条件分布, regular conditional distribution, 179
- 正向不变集, positively invariant set, 406
- 正定核, positive definite kernel, 84
- 正权支撑, positive-weight support, 337
- 正规方程, normal equations, 113
- 残差, residual, 144
- 比率割, RatioCut, 360
- 求解误差, solution error, 511
- 注意力, attention, 117
- 活跃, active, 298
- 流, flow, 354
- 流形, manifold, 152
- 测地线, geodesic, 157
- 测地距离, geodesic distance, 156
- 测度, measure, 27
- 测度空间, measure space, 27
- 消元, elimination, 342
- 深度优先搜索, depth-first search, 341
- 混叠, aliasing, 385
- 混合范数, mixed norm, 131
- 混合速度, mixing rate, 218
- 渐近稳定, asymptotically stable, 403
- 游走, walk, 338
- 满射, surjective function, 4
- 满足, satisfy, 324
- 滤波分布, filtering distribution, 409
- 滤过, filtration, 219
- 潜在点, latent point, 147
- 潜在结果, potential outcome, 299
- Wolfe 曲率条件, Wolfe curvature condition, 57
- Woodbury 恒等式, Woodbury identity, 134