



MACHINE LEARNING NOTES

机器学习笔记

卷一：数学准备

施晓罡

2026 年 · 第一版



MACHINE LEARNING NOTES

机器学习笔记

卷一：数学准备

施晓罡

2026 年 · 第一版

机器学习笔记

MACHINE LEARNING NOTES

作者：施晓罡

版本：第一版

年份：2026

Copyright © 2026 施晓罡



Licensed under the Creative Commons Attribution-NonCommercial-NoDerivatives 4.0 International License (the "License");

You may not use this file except in compliance with the License.

You may obtain a copy of the License at

<https://creativecommons.org/licenses/by-nc-nd/4.0/>

Unless required by applicable law or agreed to in writing, software distributed under the License is distributed on an "AS IS" BASIS, WITHOUT WARRANTIES OR CONDITIONS OF ANY KIND, either express or implied. See the License for the specific language governing permissions and limitations under the License.





前言

本书目标

机器学习把数据、模型和计算连接起来，但理解一种方法，不能只记住模型名称或训练步骤。还需要知道模型能够表示什么规律，学习结论依赖哪些数据与假设，什么证据足以支持评价，以及方法进入具体应用和运行系统后会受到哪些约束。本书沿着这些联系组织内容，希望读者不仅会使用算法，也能解释一个结果为何成立、何时可信，以及怎样把它放入完整的技术过程。

本书面向已经具备基本微积分、线性代数、概率统计和编程基础，希望系统理解机器学习的读者。正文会在需要时回顾具体工具，但不以这些基础课程的完整讲解为目标。阅读后，读者应能从任务和证据出发比较模型与学习方式，并把理论条件、实验评价、应用要求和系统实现放在同一条推理链上考察。

本书内容

全书分为六卷。第一卷“数学准备”建立分析、代数、概率、离散结构与动态决策的共同语言。第二卷“基础、理论和可信性”说明学习如何发生、学习保证依赖哪些条件，以及可靠性、鲁棒性、公平性和隐私等可信要求应由什么证据支持。第三卷“模型”考察经典模型、神经网络模型和概率图模型的结构、推断与学习。第四卷“范式”转向经验和知识的获得方式，讨论交互反馈、有限标注以及任务变化下如何学习、复用和迁移知识。前四卷提供数学工具、分析依据和方法选择，后两卷把这些选择放入实际约束。第五卷“应用”围绕自然语言处理、图像处理、推荐与搜索，说明任务目标、数据形态、模型和评价方式如何相互制约。第六卷“系统”连接数据准备、训练计算、部署服务与运行维护，考察方法如何成为可持续运行的机器学习系统。这样的次序并不表示建模、应用和系统彼此割裂：应用需求决定评价口径，系统条件限制可用方法，而运行中的证据又会促使模型和学习过程重新调整。

参考资料

下面按内容列出可与本书配合阅读的教材。每本书的侧重点不同，读者可以根据正在阅读的卷和需要补充的问题选择查阅，不必按列表顺序通读。

综合与基础

- Mitchell 的 *Machine Learning* 从概念学习、归纳偏置和代表性算法出发，适合查阅机器学习的基本问题和早期统一框架。
- Bishop 的 *Pattern Recognition and Machine Learning* 将概率建模、决策理论、核方法和近似推断联系起来，适合查阅概率视角下的模型与推断方法。
- 周志华的《机器学习》覆盖常用模型、学习理论和实践问题，适合按任务比较方法的基本假设与用途。
- 李航的《统计学习方法（第2版）》以统计机器学习为定位，适合按模型查阅定义、算法和数学推导。
- Deisenroth、Faisal 和 Ong 的 *Mathematics for Machine Learning* 适合补充线性代数、解析几何、矩阵微积分、概率与优化等数学工具。

统计学习与学习理论

- Hastie、Tibshirani 和 Friedman 的 *The Elements of Statistical Learning* 适合查阅回归、分类、正则化、模型选择和统计学习方法。
- Shalev-Shwartz 和 Ben-David 的 *Understanding Machine Learning: From Theory to Algorithms* 适合查阅 PAC 框架、复杂度、泛化界与优化基础。
- Mohri、Rostamizadeh 和 Talwalkar 的 *Foundations of Machine Learning* 适合查阅学习界、核方法、在线学习及其理论保证。
- James、Witten、Hastie 和 Tibshirani 的 *An Introduction to Statistical Learning* 适合结合 R 实例理解回归、分类、重采样、正则化、树模型和无监督学习。

概率模型与图模型

- Murphy 的 *Machine Learning: A Probabilistic Perspective* 以概率视角组织监督学习、无监督学习、潜变量模型和图模型，适合查阅模型间的联系。

- Murphy 的 *Probabilistic Machine Learning: An Introduction* 适合查阅现代概率机器学习的统一记号、计算方法和模型实例。
- Murphy 的 *Probabilistic Machine Learning: Advanced Topics* 适合查阅深度生成模型、状态空间模型、贝叶斯优化和相关近似推断方法。
- Koller 和 Friedman 的 *Probabilistic Graphical Models: Principles and Techniques* 适合系统查阅图模型的表示、精确与近似推断以及参数和结构学习。
- Rasmussen 和 Williams 的 *Gaussian Processes for Machine Learning* 适合深入理解高斯过程、核函数、贝叶斯预测和超参数学习。

神经网络与深度学习

- Goodfellow、Bengio 和 Courville 的 *Deep Learning* 适合查阅神经网络表示、优化、正则化和深度生成模型。
- Bishop 和 Bishop 的 *Deep Learning: Foundations and Concepts* 从概率基础连接常用架构与训练方法，适合查阅相应概念和推导。
- 邱锡鹏的《神经网络与深度学习》适合查阅前馈、卷积、循环、注意力网络及其训练方法。
- Zhang、Lipton、李沐和 Smola 的 *Dive into Deep Learning* 适合结合可运行代码理解神经网络的实现、训练与调参过程。
- Géron 的 *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow* 适合查阅从数据准备、模型训练到评估和部署的实践流程。

强化学习

- Sutton 和 Barto 的 *Reinforcement Learning: An Introduction* 适合查阅马尔可夫决策过程、价值方法、策略方法与函数逼近。
- Szepesvári 的 *Algorithms for Reinforcement Learning* 适合查阅动态规划、Monte Carlo、时序差分和函数逼近算法的数学形式与分析。

应用与系统

- Manning、Raghavan 和 Schütze 的 *Introduction to Information Retrieval* 适合查阅文本表示、索引、检索模型和评价方法。
- Huyen 的 *Designing Machine Learning Systems* 从数据、训练、部署与监控讨论机器学习系统设计，适合查阅模型进入生产环境后的工程约束。

- Jurafsky 和 Martin 的 *Speech and Language Processing* 适合查阅自然语言与语音处理中的语言模型、序列标注、句法分析和语音识别。
- Szeliski 的 *Computer Vision: Algorithms and Applications* 适合查阅成像、特征、几何、识别与图像合成方法。
- Aggarwal 的 *Recommender Systems: The Textbook* 适合查阅协同过滤、基于内容的推荐、矩阵分解和推荐评价。
- Kleppmann 和 Riccomini 的 *Designing Data-Intensive Applications* 适合查阅存储、复制、分区、事务以及流式与批量处理的系统取舍。

上述教材的完整出版信息列于卷末参考文献。

数学符号

下表汇总全书反复使用的记号。各章若赋予符号更具体的含义，会在首次使用时另行说明。

对象与线性代数

对象	常用记号	含义
数集	$\mathbb{N}, \mathbb{Z}, \mathbb{R}, \mathbb{R}_+$	自然数集、整数集、实数集和非负实数集
集合与关系	$x \in A, A \subseteq B, A \cup B, A \cap B, A $	元素属于集合、子集、并集、交集和有限集合的基数
标量	$a, x, \lambda \in \mathbb{R}$	单个数值；小写斜体字母通常表示标量
向量	$\mathbf{x}, \mathbf{w} \in \mathbb{R}^d$	d 维向量；加粗小写字母表示向量
矩阵	$\mathbf{A} \in \mathbb{R}^{m \times n}, \mathbf{A}_{i,j}$	m 行 n 列矩阵及其第 i 行、第 j 列元素
数据与样本	$\mathcal{D} = \{(\mathbf{x}_i, y_i)\}_{i=1}^n$	含 n 个输入标签对的数据集；下标 i 表示样本索引
切片与迭代	$\mathbf{A}_{i,:}, \mathbf{A}_{:,j}, \mathbf{w}^{(t)}$	矩阵的第 i 行、第 j 列，以及第 t 次迭代的向量
Kronecker delta	$\delta_{i,j}$	当 $i = j$ 时取 1，否则取 0
矩阵变换	$\mathbf{A}^\top, \mathbf{A}^{-1}, \mathbf{A}^\dagger, \mathbf{I}_d, \text{tr}(\mathbf{A})$	转置、逆、伪逆、 d 阶单位矩阵和矩阵的迹
代数运算	$\langle \mathbf{x}, \mathbf{y} \rangle, \mathbf{x}^\top \mathbf{A} \mathbf{x}, \sum_i a_i, \prod_i a_i$	内积、二次型、求和与连乘
函数与模型	$f: \mathcal{X} \rightarrow \mathcal{Y}, h_{\mathbf{w}}(\mathbf{x})$	从输入空间到输出空间的函数，以及参数为 $\mathbf{w}$ 的模型
范数与距离	$\ \mathbf{x}\ _p, d(\mathbf{x}, \mathbf{y})$	p 范数与两对象之间的距离；具体定义由上下文给出

微积分与优化

对象	常用记号	含义
导数与梯度	$\frac{df}{dx}, \nabla_{\mathbf{w}} L(\mathbf{w})$	一元导数，以及标量值函数对参数向量的梯度
Jacobian 与 Hessian	$\nabla_{\mathbf{x}} \mathbf{f}, \nabla_{\mathbf{x}}^2 f$	向量值函数的一阶偏导矩阵，以及标量值函数的二阶偏导矩阵
渐近阶	$f(n) = \mathcal{O}(g(n))$	函数增长率的渐近上界
最优化	$\min_{\mathbf{w}} L(\mathbf{w}), \mathbf{w}^* \in \arg \min_{\mathbf{w}} L(\mathbf{w})$	最小目标值与取得最小值的参数；最大化使用 $\max$ 和 $\arg \max$

概率与信息论

对象	常用记号	含义
随机变量与实现	$X, \mathbf{X}, x, \mathbf{x}, p_X(x)$	随机标量、随机向量及其实现值； p_X 表示概率质量或密度函数
联合与条件概率	$p(x, y), p(x \mid y)$	随机变量实现值的联合概率与条件概率
边缘概率	$p(x) = \sum_y p(x, y), p(x) = \int p(x, y) \mathrm{d}y$	分别对离散变量求和或对连续变量积分得到的边缘概率
独立性与抽样	$X \perp Y, X \perp Y \mid Z, X_i \overset{\text{i.i.d.}}{\sim} p$	独立、给定 Z 条件独立，以及独立同分布抽样
矩与相关性	$\mathbb{E}[X], \text{Var}(X), \text{Cov}(X, Y)$	期望、方差和协方差
常用分布	$\text{Bernoulli}(p), \text{Cat}(\boldsymbol{\pi}), \mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma})$	伯努利分布、类别分布和多元高斯分布
事件指示函数	$\mathbb{I}\{A\}$	事件 A 成立时取 1，否则取 0
信息量	$H(p), H(p, q), \text{KL}(p\ q)$	熵、交叉熵和分布 p 相对于 q 的 KL 散度
概率正比关系	$p(\mathbf{x}) \propto q(\mathbf{x})$	忽略归一化常数时的概率正比关系

目录

第一部分	计数、分析与优化	1
第 1 章	数学对象与逻辑	3
1.1	集合与关系	4
1.2	函数、函数族与取值范围	7
1.3	索引族的汇总与递推	13
1.4	命题与证明	17
1.5	本章小结	27
第 2 章	计数与计算	29
2.1	候选空间的结构与计数	29
2.2	候选空间上的约束与求解	49
2.3	问题族的可计算性与复杂度	60
2.4	本章小结	67
第 3 章	测度与分析	69
3.1	集合的距离、权重与可测范围	69
3.2	序列的极限、累计与迭代收敛	75
3.3	函数的连续性与局部变化	84
3.4	函数的可测性与整体关系	104
3.5	函数列的收敛与性质保持	117
3.6	本章小结	129
第 4 章	最优化	131
4.1	优化问题的定义与基本性质	132
4.2	无约束光滑目标的求解	139
4.3	无约束非光滑目标的求解	149

4.4	有约束优化的求解	154
4.5	计算预算有限时的近似优化	172
4.6	多目标、对抗与双层优化	182
4.7	本章小结	189

第 5 章	函数空间	190
5.1	函数空间与基本运算	190
5.2	函数空间中的投影与逼近	200
5.3	函数空间上的算子	216
5.4	函数空间上的优化	229
5.5	本章小结	238

第二部分

线性和非线性空间

241

第 6 章	线性空间	243
6.1	线性对象的空间与表示	243
6.2	线性变换的表示、运算与函数	250
6.3	线性变换的逆与方程求解	258
6.4	线性变换的幂与谱分析	270
6.5	线性变换的近似与压缩	278
6.6	线性变换的扰动与稳定性	289
6.7	本章小结	302

第 7 章	非线性空间与流形	304
7.1	非线性空间的表示	304
7.2	非线性空间的局部线性化	317
7.3	流形上相同切空间下的度量、距离与运动	322
7.4	流形上不同切空间的比较与曲率	326
7.5	流形上的优化	336
7.6	本章小结	347

第三部分

图与信号

349

第 8 章	信号的表示与计算	351
8.1	信号的对象与结构	351
8.2	信号的表示与分解	357
8.3	信号的运算与映射	366

8.4	信号的采样与恢复	383
8.5	本章小结	389
第 9 章	图的表示与计算	391
9.1	图的对象与表示	392
9.2	图上的关系、路径和遍历	395
9.3	图的划分与简化	401
9.4	图上的约束选择与优化	413
9.5	图上的函数与传播	428
9.6	本章小结	441
第四部分	随机变量、分布与因果响应	443
第 10 章	随机变量	445
10.1	随机变量的定义	445
10.2	随机变量之间的关系	459
10.3	随机变量的运算与变换	473
10.4	随机序列和随机过程	480
10.5	随机变量的推断	534
10.6	本章小结	576
第 11 章	随机分布	578
11.1	随机分布的信息量	578
11.2	随机分布之间的关系	582
11.3	随机分布扰动与任务稳定性	599
11.4	随机分布空间上的优化	604
11.5	本章小结	622
第 12 章	因果响应	624
12.1	因果响应的表示	624
12.2	因果响应的比较与变化	628
12.3	给定事实后的因果响应	632
12.4	因果响应的推断	638
12.5	因果生成结构的表示	648
12.6	因果生成结构的推断	654
12.7	本章小结	659

第五部分	演化、控制、决策与博弈	661
第 13 章	行动和状态	663
13.1	行动与状态的演化模型	663
13.2	状态轨迹的求解与计算	666
13.3	状态轨迹的极限与稳定	678
13.4	随机状态与随机轨迹	686
13.5	随机状态的观测与推断	712
13.6	本章小结	721
第 14 章	策略的实现与轨迹控制	723
14.1	策略的实现与可达轨迹	723
14.2	策略的轨迹收敛与稳定	728
14.3	策略的调节与跟踪	739
14.4	策略的约束与安全	746
14.5	本章小结	753
第 15 章	策略的价值与优化	754
15.1	策略的表示与价值	754
15.2	策略的轨迹价值与风险	758
15.3	策略的轨迹价值计算	766
15.4	策略的轨迹价值优化	773
15.5	本章小结	794
第 16 章	多方策略的响应与演化	795
16.1	策略的多方行动与信息	795
16.2	策略的多方价值	801
16.3	策略的多方响应与均衡	807
16.4	策略的多方演化与稳定	821
16.5	策略的多方累积表现	827
16.6	本章小结	841
第六部分	数学与机器学习	843
第 17 章	数学基础与后续研究	845
17.1	学习的组成：数据、目标与学习方法	845
17.2	机器学习问题的数学表述	853

17.3	数学问题的归类、形式化与分析方法	869
17.4	本章小结	899
参考文献		901
索引		906

第一部分

计数、分析与优化

Counting, Analysis and Optimization



阅读指引

训练一个模型，需要把任务写成数学问题，再判断它是否有解、怎样计算，以及近似结果与所求答案相差多少。只会代入公式，还不足以回答这些问题。本部分从这些需要出发，建立后续各卷反复使用的数学语言和求解工具。

第1章“数学对象与逻辑”统一集合、函数、关系、量词和证明方法，使后文能够准确说明讨论对象与结论范围。第2章“计数与计算”研究有限候选的规模、组合结构、可计算性与复杂度。第3章“测度与分析”把距离、极限、连续、微分、测度和积分组织成描述变化的共同语言。第4章“最优化”讨论如何在无约束、约束、多目标和近似计算条件下寻找解。第5章“函数空间”把有限维向量上的距离、投影、算子和逼近推广到以函数为元素的空间。

这些工具分别回答不同的问题：计数说明候选有多少，分析说明对象怎样变化，优化说明怎样选择，函数空间则处理未知量本身是一整个函数的情形。掌握这些区别，才能进一步判断模型能表示什么、训练在寻找什么，以及误差来自计算近似还是有限数据。

数学对象与逻辑

机器学习中的公式往往把许多计算压缩到一行。例如，要汇总若干样本的预测误差，可以把各个样本的平方误差相加。这种把有限个数相加的表达式称为有限和：若三个平方误差分别为 $a_1 = 1$ 、 $a_2 = 4$ 和 $a_3 = 9$ ，则

$$\sum_{i=1}^3 a_i = a_1 + a_2 + a_3 = 1 + 4 + 9 = 14.$$

求和号 $\sum$ 把逐项相加的计算写得更紧凑，下方的 $i = 1$ 与上方的 3 说明从第 1 项加到第 3 项。

把这一计算用于预测时，需要先说明每个符号代表什么。设有 $n \geq 1$ 个样本 $(\mathbf{x}_i, y_i) \in \mathbb{R}^d \times \mathbb{R}$ ，其中 $i = 1, \dots, n$ 。向量 $\mathbf{x}_i$ 记录第 i 个样本的 d 个输入特征，实数 y_i 是要预测的数值。选择参数向量 $\mathbf{w} \in \mathbb{R}^d$ 后，用 $\mathbf{w}^\top \mathbf{x}_i = \sum_{j=1}^d w_j x_{i,j}$ 作预测，也就是把各项特征乘以相应参数后相加。再取系数 $\lambda \geq 0$ ，可以把预测误差和参数大小合成目标函数

$$F(\mathbf{w}) = \frac{1}{2n} \sum_{i=1}^n (\mathbf{w}^\top \mathbf{x}_i - y_i)^2 + \frac{\lambda}{2} \|\mathbf{w}\|_2^2. \quad (1.1)$$

相应的最小二乘问题是求 $\min_{\mathbf{w} \in \mathbb{R}^d} F(\mathbf{w})$ 。前一项是样本平方误差的平均值乘以 $1/2$ ；后一项用 $\|\mathbf{w}\|_2^2 = \sum_{j=1}^d w_j^2$ 度量参数大小，再乘以 $\lambda/2$ 作为惩罚，称为正则项。 λ 规定这项惩罚的权重，取 $\lambda = 0$ 就只比较预测误差。求最小值时，我们需要在允许的参数范围内，找出使这两项之和最小的参数。要准确理解这项任务，就必须知道参数可以取哪些值、求和包含哪些样本，以及怎样比较两个参数的表现。若省略 $\mathbf{w} \in \mathbb{R}^d$ ，读者便不知道优化在哪个集合上进行；若误把 λ 取成负数，这一项就可能奖励更大的参数；若把“存在一个参数对所有样本都预测正确”误写成“对每个样本都存在一个预测正确的参数”，结论甚至会完全改变。

本章把这些容易隐没在公式里的约定展开。要说明哪些参数可以使用，需要集合；要说明参数之间怎样分类和比较，需要关系。把参数送入目标函数之前，还要区分函数、输入与函数值；组织多个样本或多次迭代时，则要给每个对象明确的编号。对象和运算写清以后，我们才能用命题准确

表达结论，并用证明检查结论是否真的由条件推出。本章先解决怎样把任务写准确、怎样核对结论的问题。候选数量与程序能力由第2章研究，极限和连续变化由第3章研究。

1.1 集合与关系

在一组参数中挑选解时，我们需要知道哪些参数允许使用；比较两个参数时，还需要约定比较什么。前一项要求用集合说明讨论范围，后一项要求用关系说明分类或比较的标准。

1.1.1 集合及其运算

在比较参数或讨论样本之前，必须先确定哪些对象属于讨论范围。集合(set)把范围内的对象作为一个整体；它记录成员资格，而不记录成员出现的次数。若对象 x 属于集合 X ，记作 $x \in X$ ；不属于则记作 $x \notin X$ 。若 X 的每个元素也属于 Y ，称 X 为 Y 的子集(subset)，记作 $X \subseteq Y$ 。没有元素的集合是空集 $\emptyset$ 。 $x \in X$ 比较的是对象与集合， $A \subseteq X$ 比较的是两个集合；例如 $1 \in \{1, 2\}$ 而 $\{1\} \subseteq \{1, 2\}$ ，不能交换这两个符号。

同时满足两项条件和至少满足其中一项条件，对应不同的集合运算。对集合 X, Y ,

$$X \cap Y = \{x : x \in X \text{ 且 } x \in Y\},$$

$$X \cup Y = \{x : x \in X \text{ 或 } x \in Y\},$$

$$X \setminus Y = \{x : x \in X \text{ 且 } x \notin Y\}.$$

它们分别称为交集、并集与差集。这里的“或”包含两个条件同时成立的情形。若已固定讨论全集 U ， X 的补集是 $X^c = U \setminus X$ ；换了 U ，补集也可能改变。例如， C 是满足资源约束的参数集合， D 是使模型有定义的参数集合，真正允许使用的参数属于 $C \cap D$ ，而 $C \setminus D$ 中的参数虽然满足资源约束，却使模型无法计算输出。

取 $U = \{1, 2, 3, 4\}$ 、 $C = \{1, 2, 3\}$ 、 $D = \{2, 3, 4\}$ ，则 $C \cap D = \{2, 3\}$ 、 $C \cup D = U$ 、 $C \setminus D = \{1\}$ 、 $C^c = \{4\}$ 。这些运算依据的都是对象是否属于集合。要证明一个集合恒等式，也可以沿用这个依据逐个比较成员资格。两个集合相等，当且仅当它们包含完全相同的元素；因此证明 $A = B$ 可以分成 $A \subseteq B$ 与 $B \subseteq A$ 两个方向。

集合的描述常有两种方式。列举法直接写出元素，如 $A = \{1, 2, 3\}$ ；条件法写成

$$A = \{i \in \mathbb{Z} : 1 \leq i \leq 3\}.$$

冒号右侧是成员必须满足的条件。集合只记录元素是否属于其中，不记录排列顺序，也不重复计数。因此 $\{1, 2, 3\}$ 、 $\{3, 2, 1\}$ 和 $\{1, 1, 2, 3\}$ 表示同一个

集合。需要顺序或重复次数时，应使用第 1.3.1 节的索引族：给每次出现另配一个编号，即使数值相同也能区分。编号本身与编号的读取顺序还要分别说明。

一个带标签样本同时包含输入和标签，仅给出两个各自的取值集合，还没有说明它们怎样组成一个对象。为此，把来自两个集合 X 与 Y 的元素配成有序对。全部这样的配对组成 笛卡尔积 (Cartesian product)：

$$X \times Y = \{(x, y) : x \in X, y \in Y\}.$$

“有序”意味着 (x, y) 与 (y, x) 通常不是同一个对象。一个带标签样本可以表示为 $(\mathbf{x}, y) \in \mathbb{R}^d \times \mathbb{R}$ ；包含 n 个样本的数据集则可以先看成该集合中的一个长度为 n 的序列。这样写清了一个样本的组成，却还没有对样本怎样产生作任何概率假设。

若算法要从一组特征中挑选若干个特征，候选对象就不再是单个特征，而是特征子集。把集合 X 的全部子集再收集成一个集合，得到 幂集 (power set) $\mathcal{P}(X)$ 。如果 $X = \{a, b\}$ ，那么

$$\mathcal{P}(X) = \{\emptyset, \{a\}, \{b\}, \{a, b\}\}.$$

幂集在后文有两类用途。在概率模型中，事件是样本空间 Ω 的子集；实际允许赋予概率的事件可能只包括其中一部分子集，而且这些子集必须满足相应的运算规则。有限或可数离散样本空间中常取完整幂集。幂集也可以描述算法可能选择的特征子集或边集合。若只允许选择满足特定条件的特征子集，就应把这些子集组成另一个集合族，而不能把全部子集都当作候选。概率事件族需要满足的闭包条件将在概率论部分说明。

1.1.2 二元关系

两个对象可以不同，却在当前问题中起同一种作用。例如，不同参数可能给出同一个预测函数，同一条过原点直线上的非零向量也可能表示同一个无向方向。要把这种“按某种标准视为相同”写清楚，需要先约定对象之间满足什么关系，再检查该关系能否给出不相交的分类。

集合 X 与 Y 之间的二元关系 (binary relation) 是 $X \times Y$ 的一个子集 R 。写 xRy 表示 $(x, y) \in R$ 。在一个二元关系中，同一个 x 可以与多个 y 配对，也可以不与任何 y 配对。例如，“不大于”是 $\mathbb{R}$ 上的关系，“样本 i 与样本 j 之间有边”是索引集合上的关系。

定义 1.1 等价关系与等价类 定义在同一个集合 X 上的关系 R 若对任意 $x, y, z \in X$ 满足

- 对每个 $x \in X$ 都有 xRx ;
- xRy 蕴含 yRx ;
- xRy 且 yRz 蕴含 xRz ,

就称为等价关系 (equivalence relation), 即能够把对象按同一标准分组的的关系。三条性质分别称为反身性 (也称自反性)、对称性与传递性。给定 $x \in X$, 与 x 等价的对象组成它的等价类 (equivalence class)

$$[x]_R = \{y \in X : yRx\}.$$

全部等价类组成的集合记为 X/R , 称为商集 (quotient set)。

这些条件为何能得到不重叠的分类? 反身性保证 $x \in [x]_R$, 所以等价类覆盖 X 。若 $[x]_R$ 与 $[y]_R$ 共有元素 z , 由 zRx 、 zRy 、对称性与传递性可得 xRy 。对任意 $u \in [x]_R$, uRx 和 xRy 又给出 uRy , 于是 $[x]_R \subseteq [y]_R$; 交换 x, y 得到反向包含。因此两个等价类要么相同, 要么不相交, 而不是部分重叠。

例如, 按整数除以 2 的余数分类, 奇数属于一类, 偶数属于另一类。在 $\mathbb{R}^2 \setminus \{0\}$ 上规定 $\mathbf{x} \sim \mathbf{y}$ 当且仅当存在 $c \in \mathbb{R} \setminus \{0\}$ 使 $\mathbf{x} = c\mathbf{y}$, 那么同一条过原点直线上的非零向量属于同一个等价类。取 $c = 1$ 得到反身性, 取 $1/c$ 得到对称性, 相乘比例系数得到传递性。这里允许负比例, 所以 $\mathbf{x}$ 与 $-\mathbf{x}$ 属于同一类; 若保留朝向, 应把条件改为 $c > 0$, 所得分类也随之改变。后文讨论参数不可识别时, 不同参数也可能因为产生同一个可观测对象而落入同一等价类。

分类关心哪些对象可以合并, 比较优劣则关心哪个对象不劣于另一个。例如, 一个方案占用的内存较少, 另一个方案运行得较快, 二者未必能按优劣排出先后。要保留这种“有些对象能比较、有些不能”的情形, 需要另一种关系。

定义 1.2 偏序关系 集合 X 上的偏序关系 (partial order) R 是一种允许部分对象互不可比的比较关系。它对任意 $x, y, z \in X$ 满足反身性 xRx 、传递性, 以及反对称性: xRy 且 yRx 时必须有 $x = y$ 。若任意两个元素还至少满足 xRy 或 yRx 中的一个, 则称为全序 (total order)。

反对称性限制的是两个不同元素之间的关系：若 $x \neq y$, xRy 与 yRx 不能同时成立。偏序还要求每个元素与自身满足关系，即 xRx ；因此反对称性与反身性并不冲突。等价关系允许不同对象互相等价，偏序关系则把互相“不大于”的对象限制为同一个对象。集合包含关系 $\subseteq$ 就是幂集上的偏序，因为双向包含意味着集合相等。偏序中的两个元素未必可比较，例如 $\{1\}$ 和 $\{2\}$ 都不是对方的子集。这一点会在多目标优化中再次出现：两个方案可能各自在一个目标上更好，因而不能排成一条总的优劣顺序。

1.2 函数、函数族与取值范围

关系可以记录多种配对，函数则要求每个输入有唯一输出。确定输出后，我们还要回答三个问题：能否从输出恢复输入，怎样用参数选择不同的函数，以及怎样比较这些函数的取值。这三项要求分别引出逆映射、函数族和极值。

1.2.1 映射及其运算

如果一个输入可以对应多个输出，关系已经足够；若要把“给定输入后求值”规定成确定操作，就需要唯一性。函数 (function)，也称映射 (mapping)， $f : X \rightarrow Y$ 为每个 $x \in X$ 指定唯一的 $f(x) \in Y$ 。 X 称为定义域 (domain)，规定允许输入什么； Y 称为陪域 (codomain)，规定输出属于哪个集合。函数的配对关系是 $X \times Y$ 的子集，但它额外要求每个 x 恰好出现一个配对。

以平方变换 $f : \mathbb{R} \rightarrow \mathbb{R}$, $f(x) = x^2$ 为例。给定输入 -2 可以算出 $f(-2) = 4$ ，但陪域中的负数不会成为输出。对 $A \subseteq X$ ，实际输出组成的集合

$$f(A) = \{f(x) : x \in A\}$$

称为 A 的像 (image)； $f(X)$ 是整个函数的像，也称值域。这里 $f(\mathbb{R}) = [0, \infty)$ ，而 $f(\{-2, 1\}) = \{1, 4\}$ 。像是实际结果，陪域是预先声明的范围，不能因二者都谈输出就混用。

反过来，若只知道输出必须落在 $B \subseteq Y$ 中，可以筛出全部合格输入：

$$f^{-1}(B) = \{x \in X : f(x) \in B\}. \quad (1.2)$$

这称为 B 在 f 下的原像 (preimage)，即把输出条件转成输入集合。平方变换给出

$$\begin{aligned} f^{-1}(\{1\}) &= \{-1, 1\}, \\ f^{-1}([1, 4]) &= [-2, -1] \cup [1, 2], \\ f^{-1}(\{-1\}) &= \emptyset. \end{aligned}$$

原像可以含多个元素，也可以为空；记号 $f^{-1}(B)$ 没有断言存在一个反向求值的函数。尤其是 $f^{-1}(\{1\})$ 中的花括号说明我们在对集合做运算，而不是把数 1 送入某个已经定义好的逆函数。

多个变换连接时，必须检查后一个能否接收前一个的输出。给定 $f : X \rightarrow Y$ 与 $g : Y \rightarrow Z$ ，它们的复合（composition）是把 f 的输出交给 g ：

$$(g \circ f)(x) = g(f(x)), \quad g \circ f : X \rightarrow Z.$$

复合能够计算的前提是 f 的每个实际输出都在 g 的定义域中。即使 g 未在整个 Y 上定义，只要它在 $f(X)$ 上都有定义， $g(f(x))$ 仍能对每个 $x \in X$ 计算。例如对平方变换再作 $h : \mathbb{R} \rightarrow \mathbb{R}, h(y) = y + 1$ ，得到 $(h \circ f)(x) = x^2 + 1$ ；次序交换后却是 $(f \circ h)(x) = (x + 1)^2$ ，在 $x = 1$ 时分别为 2 与 4。书写复合时右边的函数先作用，这与从左到右读汉语句子的习惯不同。

复合虽然通常不交换，却满足结合律。若 $f : X \rightarrow Y, g : Y \rightarrow Z, h : Z \rightarrow U$ ，则两种括号方式对每个 x 都产生 $h(g(f(x)))$ ，所以

$$h \circ (g \circ f) = (h \circ g) \circ f.$$

不改变输入的恒等映射（identity map） $\text{id}_X(x) = x$ 则满足 $f \circ \text{id}_X = f$ 与 $\text{id}_Y \circ f = f$ 。它提供了判断反向操作是否真的恢复原对象的标准。

不过，平方变换把 -2 和 2 都送到 4，仅凭输出 4 无法判断原输入；输出 -1 则根本没有原输入。要让反向求值在整个陪域上成立，就必须分别排除“原输入不唯一”和“原输入不存在”这两种问题。

定义 1.3 单射、满射与逆映射 函数 $f : X \rightarrow Y$ 若满足 $f(x_1) = f(x_2)$ 必然推出 $x_1 = x_2$ ，称为单射（injective function）；它不合并不同输入。若每个 $y \in Y$ 都等于某个 $f(x)$ ，称为满射（surjective function）；它覆盖整个陪域。同时满足二者时称为双射（bijection）。双射的逆映射（inverse map） $f^{-1} : Y \rightarrow X$ 把每个输出送回唯一的原输入，满足

$$f^{-1} \circ f = \text{id}_X, \quad f \circ f^{-1} = \text{id}_Y.$$

对一个给定输出，单射保证原输入至多有一个，满射保证至少有一个。因此，在整个陪域上恢复唯一输入必须同时具备两项性质。反过来，若某个反向映射满足上面两个恒等式，对 $f(x_1) = f(x_2)$ 作用它就得到 $x_1 = x_2$ ，而每个 $y = f(f^{-1}(y))$ 都在像中，所以 f 确实是双射。

平方变换在 $\mathbb{R} \rightarrow \mathbb{R}$ 上既不是单射，也不是满射。只把陪域改为 $[0, \infty)$ 能得到满射，却仍分不清 x 与 $-x$ 。再把定义域也限制到 $[0, \infty)$ ，得到 $g : [0, \infty) \rightarrow [0, \infty), g(x) = x^2$ ，才有逆映射 $g^{-1}(y) = \sqrt{y}$ 。若 f 是单射但

不是满射，可以把它的陪域改为实际的像 $f(X)$ 。这样每个输出都有唯一原输入，便能定义逆映射。图 1.1 用平方变换的有限限制展示这个差别：左侧沿指向 1 的所有箭头找到原像，右侧每个输出只有一个箭头来源，才可以反向唯一求值。




图 1.1 原像与逆映射回答不同问题。左侧 $f : \{-1, 0, 1\} \rightarrow \{0, 1, 2\}$ 按平方取值，标出的 1 有两个原输入，2 没有原输入；原像 $f^{-1}(\{1\}) = \{-1, 1\}$ 仍有定义。右侧将定义域与陪域都限制为 $\{0, 1\}$ 得到双射 g ，实线表示正向求值，虚线表示逆映射，因而 $g^{-1}(1) = 1$ 是一个元素。两侧均为精确的有限映射。

反求复合结果还要倒转操作次序。若 $f : X \rightarrow Y$ 与 $g : Y \rightarrow Z$ 都是双射，从 z 恢复 x 必须先撤销 g ，再撤销 f ，因此

$$(g \circ f)^{-1} = f^{-1} \circ g^{-1}. \quad (1.3)$$

验证时，对 $x \in X$ 与 $z \in Z$ 分别有

$$\begin{aligned} f^{-1}(g^{-1}(g(f(x)))) &= f^{-1}(f(x)) = x, \\ g(f(f^{-1}(g^{-1}(z)))) &= g(g^{-1}(z)) = z. \end{aligned}$$

这两个方向分别检查了两个恒等映射条件。在非负输入上先平方、再加 1，反向操作便是先减 1、再开平方： $z \mapsto \sqrt{z-1}$ ，其定义域为 $[1, \infty)$ 。直接写成 $\sqrt{z-1}$ 既颠倒了撤销次序，也不能恢复原输入。

1.2.2 函数族与参数化

前面把输入送入一个固定函数；选择模型时则要在的一组函数中挑选一个对象。必须区分函数 f 、输入 x 与函数值 $f(x)$ 。式 (1.1) 中的 F 是把每个参数向量映射到一个实数的函数， $F(\mathbf{w})$ 才是参数 $\mathbf{w}$ 对应的目标值。若要讨论

一组候选函数，应把它们写成函数集合，这样的集合称为函数族（family of functions）。例如

$$f_{\mathbf{w}} : \mathbb{R}^d \rightarrow \mathbb{R}, \quad f_{\mathbf{w}}(\mathbf{x}) = \mathbf{w}^\top \mathbf{x}, \quad \mathcal{F} = \{f_{\mathbf{w}} : \mathbf{w} \in \mathbb{R}^d\}.$$

这里 $\mathbf{w}$ 索引函数, $\mathbf{x}$ 是函数的输入。混淆这两个角色, 会使“优化参数”和“对新输入求值”看起来像同一步操作。更准确地说, 参数化 (parameterization) 用参数给候选函数编号, 给出了映射 $\mathbf{w} \mapsto f_{\mathbf{w}}$ 。它的输入是参数向量, 输出却是一个函数, 而不是这个函数在某个固定输入上的函数值。这个映射若不是单射, 不同参数就会表示同一个函数; 因此参数集合与由它表示的函数集合也不能直接视为同一个集合。

定义 1.4 函数参数化的可识别性 给定参数集合 Θ 与函数族 $\{f_{\theta} : X \rightarrow Y : \theta \in \Theta\}$ 。若 $f_{\theta} = f_{\theta'}$ 蕴含 $\theta = \theta'$, 即 $\theta \mapsto f_{\theta}$ 为单射, 则称这一函数参数化可识别 (identifiable); 也就是说, 完整函数唯一确定其参数。否则称为不可识别。

这里的相等比较整个定义域上的函数。若只观察部分输入, 即使整个函数族的参数化可识别, 这部分观测也可能不足以辨认参数。

例如, 一元仿射函数 $f_{a,b}(x) = ax + b$ 在 $\mathbb{R}$ 上相等, 意味着在 $x = 0$ 处有 $b = b'$, 在 $x = 1$ 处又有 $a + b = a' + b'$, 从而 $a = a'$ 。这说明完整函数的参数表示唯一。如果只观察 $x = 0$ 处的输出, 便只能确定 b , 任意 a 都给出同一观测。改变的是可用的信息, 而不是可识别性的定义。

示例 1.5 参数不同而函数相同 考虑参数化函数

$$f_{a,b} : \mathbb{R} \rightarrow \mathbb{R}, \quad f_{a,b}(x) = abx, \quad (a, b) \in \mathbb{R}^2.$$

参数 $(1, 2)$ 与 $(2, 1)$ 不同, 却对每个 x 给出相同的函数值。更一般地, 只要 $c \neq 0$, $(ca, b/c)$ 与 (a, b) 表示同一个函数。由于定义域包含非零输入, 例如取 $x = 1$, 从完整的输入输出关系可以确定乘积 ab , 却不能分别确定 a 和 b 。这是参数化的不可识别性, 而不是计算精度不足。

把 $\theta \sim \theta'$ 定义为 $f_{\theta} = f_{\theta'}$, 就得到参数集合上的等价关系。每个等价类包含表示同一个函数的全部参数。函数族是函数组成的集合, 同一个函数只算一个元素; 参数索引族则还会保留表示这个函数的多个参数。可识别性回答的是完整函数能否唯一确定参数。它没有给出恢复参数的算法, 也没有保证只观察有限个输入, 或者观测带有误差时, 仍能准确恢复参数。数学表示唯一与计算上可求, 是两项需要分别论证的性质。

1.2.3 实值函数的界与极值

选择参数时，即使目标值越来越小，也未必能找到使它最小的参数。例如， $f(x) = x$ 在 $(0, 1)$ 上可以任意接近 0，却永远取不到 0。因此，比较函数值时要区分两个问题：它们能接近多低的数值，以及是否有输入真的达到这个数值。为此，先固定非空实数集合 A 。若 $l \leq a$ 对每个 $a \in A$ 成立，称 l 为下界 (lower bound)；若 $a \leq u$ 对每个 $a \in A$ 成立，称 u 为上界 (upper bound)。存在实数下界称为下有界，存在实数上界称为上有界，两者都有才称为有界。界不必属于 A ，也通常不唯一，例如 $(0, 1)$ 的下界包括 0, -1, -2。

下有界时，希望把下界推到尽可能高，又不超过任何成员。由实数的完备性，非空下有界集合有最大的下界，称为下确界 (infimum)，记作 $\inf A$ 。对称地，非空上有界集合有最小的上界，称为上确界 (supremum)，记作 $\sup A$ 。用 $\alpha = \inf A$ 表示下确界，则 $\alpha \leq a$ 对全部 $a \in A$ 成立，而且每个 $\varepsilon > 0$ 都能找到 $a \in A$ 使 $a < \alpha + \varepsilon$ 。后一条件排除了还可向上移动的下界，只要求能任意接近，不要求等号成立。类似地， $\beta = \sup A$ 除了是上界，还要求每个 $\varepsilon > 0$ 都有 $a \in A$ 使 $a > \beta - \varepsilon$ 。实数完备性将在第 3 章进一步讨论。

现在把 A 取为非空定义域 X 上的实值函数 $f : X \rightarrow \mathbb{R}$ 的像 $f(X)$ 。若 $x^* \in X$ 满足

$$\forall x \in X, \quad f(x^*) \leq f(x),$$

则 x^* 是一个全局最小点 (global minimizer)， $f(x^*)$ 是最小值。所有最小点组成集合

$$\arg \min_{x \in X} f(x) = \{x \in X : \forall z \in X, f(x) \leq f(z)\}.$$

有最小值时，这也等于 $\{x \in X : f(x) = \min_{z \in X} f(z)\}$ 。arg min 返回输入的集合，而 min 返回数值；多个输入可以取得同一个最小值。如果没有输入取得最佳数值，就没有最小点，最小点集合为空。

即使没有最小值，只要 $f(X)$ 有下界，仍有有限的下确界

$$f^* = \inf_{x \in X} f(x).$$

f^* 是 $f(X)$ 的最大下界：每个 $f(x)$ 都不小于 f^* ，并且任何更大的数都不再是下界。例如 $f(x) = x$ 、 $X = (0, 1)$ 满足 $\inf_{x \in X} f(x) = 0$ ，但不存在 $x \in X$ 使 $f(x) = 0$ 。

与下界对称，若 $f(X)$ 有上界，则其上确界记为

$$\sup_{x \in X} f(x).$$

若某个 $x^* \in X$ 达到这个数值, 便得到最大值和最大点。所有最大点组成 $\arg \max_{x \in X} f(x)$, 即满足 $f(x) \geq f(z)$ 对所有 $z \in X$ 成立的输入 x 的集合; 有最大值时,

$$\arg \max_{x \in X} f(x) = \{x \in X : f(x) = \max_{z \in X} f(z)\}.$$

它与 $\arg \min$ 一样返回输入集合, 没有最大点时该集合为空。下确界、上确界描述可逼近的边界, 最小值、最大值则额外要求边界由定义域中的元素达到。若 f 无下界, 约定 $\inf_{x \in X} f(x) = -\infty$; 若 f 无上界, 则相应上确界为 $+\infty$ 。这里的无穷符号描述没有有限界, 不是实值函数能够取到的数。

示例 1.6 同一个最优值可以对应多个输入 令 $X = [-2, 2]$, $f(x) = (x^2 - 1)^2$ 。平方非负, 且 $x = \pm 1$ 都使它为零, 所以

$$\min_{x \in X} f(x) = \inf_{x \in X} f(x) = 0, \quad \arg \min_{x \in X} f(x) = \{-1, 1\}.$$

又因为 $0 \leq x^2 \leq 4$, 有 $|x^2 - 1| \leq 3$, 于是 $f(x) \leq 9$, 等号恰在 $x = \pm 2$ 处成立。因此最大值为 9, 最大点集合为 $\{-2, 2\}$ 。最小值是一个数, 不会因为有两个最小点就变成两个最小值; 最优点是否唯一是另一个问题。

图 1.2 固定同一个函数 $f(x) = x$, 只改变定义域是否包含端点。两侧的函数值都以 0 为下确界; 右侧把 $x = 0$ 纳入定义域后, 这个下确界才由某个输入达到。比较的关键是边界点是否属于定义域, 而不是两条曲线是否趋向同一个高度。




图 1.2 同一函数 $f(x) = x$ 的边界对照。左图定义域为 $(0, 1)$ ，空心端点不属于图像，函数值可任意接近 0，却不能取到；右图定义域为 $[0, 1]$ ，实心端点 $(0, 0)$ 达到下确界。两图的下确界相同，最小点是否存在取决于可行端点是否保留。图为解决教学示例。

1.3 索引族的汇总与递推

1.3.1 索引族与序列

两个样本可能有相同的输入，但仍是两次不同的观测。若只把输入写成集合，相同的值会合并，无法知道它出现了几次。给每次出现配上编号，并记录编号对应的对象，就能保留这些信息。函数恰好可以描述这种从编号到对象的对应。

定义 1.7 索引族 给定索引集合 I 和对象集合 X ，一个索引族是映射 $a : I \rightarrow X$ 。通常把 $a(i)$ 写作 a_i ，整个族写作 $(a_i)_{i \in I}$ 。

例如 $a_1 = 1, a_2 = 1, a_3 = 4$ 组成的族 $(1, 1, 4)$ ，其取值集合却只有 $\{1, 4\}$ 。从集合无法恢复哪个编号取 1，也无法恢复 1 出现了两次。索引族保留的是从编号到对象的完整对应，而不只是这个映射的像。当 $I = \{1, \dots, n\}$ 并按整数顺序读取时，得到有限序列；当 I 为正整数集时，得到无限序列，取值为实数时通常称为数列 (sequence)。本章约定 $\mathbb{N} = \{0, 1, 2, \dots\}$ ，需要从 1 开始时写明 $n \geq 1$ 。二维数组则使用索引对 (i, j) 。索引族允许不同索引对应同一对象，而集合只保留对象是否出现；两者因此不能互相替代。一般索引集 I 未必带顺序，例如按城市名索引一组测量值时，编号并未自动规定先后。序列之所以有顺序，是因为使用了整数索引的顺序，而不是因为加了一个下标。

有了索引，就可以明确指出正在讨论哪个对象。本书通常用 i, j, k 标识元素或样本，用 n 表示样本数，用 d 表示特征维数，用带括号的上标 t 表示迭代步。例如， $\mathbf{x}_i \in \mathbb{R}^d$ 是第 i 个样本， $x_{i,j}$ 是该样本的第 j 个坐标， $\mathbf{w}^{(t)}$ 是第 t 次迭代的参数。普通上标则保留给幂： w_j^2 表示平方，而 $w_j^{(2)}$ 表示第 2 次迭代中的第 j 个坐标。若对象本身按时间排列，还应另行声明时间下标，例如 $\mathbf{z}_\tau$ 表示时刻 τ 的状态。样本编号、物理时间和算法迭代都可以取整数值，但它们索引的是不同对象，不能仅因数值相同就互换。

同样，函数族 $(f_\theta)_{\theta \in \Theta}$ 是以函数为取值对象的索引族。选定 θ 得到一个函数，选定该函数的输入 x 才得到 $f_\theta(x)$ 。索引集可以是有限的，也可以无限；这只是组织对象的方式，本身不附带收敛结论。

1.3.2 有限和与有限积

把若干误差合成一个总量，需要逐项相加；把若干比例因子连续作用于一个量，则需要逐项相乘。这两类有限运算分别用 $\sum$ 与 $\prod$ 缩写。对 $n \geq 1$ 个实数 a_i ,

$$\sum_{i=1}^n a_i = a_1 + \cdots + a_n, \quad \prod_{i=1}^n a_i = a_1 \cdots a_n.$$

例如 $a_1 = 1, a_2 = 4, a_3 = 9$ 时，有限和为 14，有限积为 36。若没有任何项，约定

$$\sum_{i \in \emptyset} a_i = 0, \quad \prod_{i \in \emptyset} a_i = 1.$$

理由是增加一个空的部分不应改变已有结果：加法需要 0，乘法需要 1。这样，逐项构造时“已有零项”的起点也能使用同一套公式。使用乘积前仍应检查零因子与符号；对全部为正的因子可以用 $\log(\prod_{i=1}^n a_i) = \sum_{i=1}^n \log a_i$ ，含零或负数时不能在实数范围直接这样做。

范围确定后，求和变量的名称不影响结果：

$$\sum_{i=1}^n a_i = \sum_{k=1}^n a_k.$$

这里 i 是哑索引 (dummy index)，只负责遍历各项，求和完成后不再自由变化。与之不同，对样本坐标作汇总时，

$$b_j = \sum_{i=1}^n x_{i,j}, \quad j = 1, \dots, d,$$

中的 j 是自由索引 (free index)：固定 j 才能知道在汇总哪个坐标。可以把求和的 i 统一改为 k ，却不能只把右侧 j 改成 k 而保留左侧 b_j 。给哑索引换名时，也不能占用式中已有的自由索引；把本式的 i 改成 j 会破坏原来的含义。

有限和中的各项可以先乘系数再相加，也可以先分别求和再乘系数。这来自加法与乘法的分配律，称为求和的线性关系。对标量 a, b 与同长度序列 (u_i) 、 (v_i) ,

$$\sum_{i=1}^n (au_i + bv_i) = a \sum_{i=1}^n u_i + b \sum_{i=1}^n v_i.$$

若权重 $\alpha_i \geq 0$ 且 $\sum_{i=1}^n \alpha_i = 1$, 则 $\sum_i \alpha_i u_i$ 称为有限加权平均 (weighted average)。普通样本平均对应 $\alpha_i = 1/n$ 。这个简单对象会成为积分与期望的有限版本：积分允许位置形成连续集合，期望则按概率分配权重。例如，章首三个平方误差的普通平均是 $(1 + 4 + 9)/3 = 14/3$ ；若权重改为 $1/2$ 、 $1/4$ 、 $1/4$ ，则加权平均是 $\frac{1}{2} \cdot 1 + \frac{1}{4} \cdot 4 + \frac{1}{4} \cdot 9 = 15/4$ 。两者使用同一组数值，改变的是各项在汇总结果中的权重。非负且和为 1 的条件还保证加权平均不越出各项范围：若每个 u_i 都在 $[m, M]$ 内，逐项乘 $\alpha_i \geq 0$ 再相加就得到 $m \leq \sum_i \alpha_i u_i \leq M$ 。若不要求权重非负且总和为 1，这个表达式只是加权和，结果可能超出各项数值的范围。

双重有限和是在一组索引对上逐项相加。对实数数组 $(a_{i,j})$,

$$\sum_{i=1}^n \sum_{j=1}^d a_{i,j} = \sum_{j=1}^d \sum_{i=1}^n a_{i,j},$$

因为两边都遍历 $\{1, \dots, n\} \times \{1, \dots, d\}$ ，每个索引对恰好贡献一次；有限实数加法的交换律和结合律允许改变遍历顺序。例如数组两行为 $(1, 2, 3)$ 和 $(4, 5, 6)$ ，按行汇总得 $6 + 15 = 21$ ，按列汇总得 $5 + 7 + 9 = 21$ 。

如果内层范围依赖外层索引，换序时范围也必须随之重写。例如

$$\sum_{i=1}^n \sum_{j=1}^i a_{i,j} = \sum_{j=1}^n \sum_{i=j}^n a_{i,j}. \quad (1.4)$$

两边的索引对都满足 $1 \leq j \leq i \leq n$ 。 $n = 3$ 时恰有六项，分别对应 $(1, 1)$ 、 $(2, 1)$ 、 $(2, 2)$ 、 $(3, 1)$ 、 $(3, 2)$ 和 $(3, 3)$ 。把右侧内层误写为 $i = 1, \dots, n$ 会多算三项。合法换序保留的是同一批项，不只是交换两个求和符号。无限级数与积分的换序还需要额外条件，不能仅从有限情形类推。

1.3.3 递推与展开

有限和也可以随着数据到来逐步计算。例如，三个平方误差 1、4、9 依次到达时，不必每收到一项就把已有各项重新相加。记 $S^{(t)}$ 为收到前 t 项后的累计值，只需保存上一轮的累计值，并把新到的一项加进去：

$$S^{(0)} = 0, \quad S^{(t+1)} = S^{(t)} + a_{t+1}, \quad t = 0, 1, 2.$$

在这个例子中, 更新依次给出 $S^{(1)} = 1$ 、 $S^{(2)} = 5$ 、 $S^{(3)} = 14$ 。第 $t+1$ 轮只需知道 $S^{(t)}$ 和新值 a_{t+1} , 而不必保存前 t 项; 展开更新则回到 $S^{(t)} = \sum_{i=1}^t a_i$ 。有限和写出累计结果, 更新规则写出怎样逐步得到这个结果。

这种从初值出发, 用已有项确定后续项的关系称为递推 (recurrence)。对这样的逐步求值规则, 更新规则与初值共同确定序列, 只有更新规则通常不能确定每一项。递推也不一定累加数值: 若某种修正每轮把当前偏差缩小一半, 从偏差 8 出发便依次得到 4、2、1。用 $e^{(t)}$ 表示第 t 轮的带符号偏差, 把 $1/2$ 推广为固定系数 $\rho \in \mathbb{R}$, 可写成

$$e^{(t+1)} = \rho e^{(t)}, \quad e^{(0)} = e_0, \quad t = 0, 1, \dots, \quad (1.5)$$

对整数 $t \geq 1$ 逐步展开得到

$$e^{(t)} = \rho^t e_0.$$

每步都有 $|e^{(t+1)}| = |\rho| |e^{(t)}|$: 当 $|\rho| < 1$ 时, 非零偏差在下一步缩小; $\rho = -1$ 使大小不变而符号交替, $|\rho| > 1$ 使非零偏差放大。若 $e_0 = 0$, 每一项都是零; 若 $\rho = 0$, 第一次更新后便一直为零。这里先由更新规则确定有限步结果; 这些结果在无限多步之后怎样变化, 将在分析章讨论。

刚才的更新只缩放已有偏差。如果每一步还引入新的计算或观测误差, 就需要把新误差也记入更新。可用下面的不等式给出误差上界:

$$e^{(t+1)} \leq \rho e^{(t)} + \delta_t, \quad 0 \leq \rho < 1, \quad (1.6)$$

其中 $e^{(t)}$ 表示第 t 步的非负误差, $\delta_t \geq 0$ 表示这一步新加入的扰动大小。这个不等式只给出下一步的误差上界, 而不指定它的精确值。再次使用递推不等式, 并利用 $\rho \geq 0$ 使不等号方向保持不变, 得到

$$\begin{aligned} e^{(2)} &\leq \rho^2 e^{(0)} + \rho \delta_0 + \delta_1, \\ e^{(3)} &\leq \rho^3 e^{(0)} + \rho^2 \delta_0 + \rho \delta_1 + \delta_2. \end{aligned}$$

新扰动加入时权重为 1, 此后每经过一轮就再乘一次 ρ 。把这组逐项相加的表达式写成有限和, 对整数 $t \geq 1$ 展开 t 步可得

$$e^{(t)} \leq \rho^t e^{(0)} + \sum_{s=0}^{t-1} \rho^{t-1-s} \delta_s. \quad (1.7)$$

第一项记录初始误差在 t 步后的权重, 第二项汇总前 t 步新加入的扰动。新加入的项经过的更新次数不同, 权重也不同; 这个有限展开还没有对无限步极限作保证。例如 $e^{(0)} = 8$ 、 $\rho = 1/2$ 、每个 $\delta_s = 1$ 时, 前三步上界依次为 5、7/2、11/4。第三步也可由展开直接算得 $8/8 + 1/4 + 1/2 + 1 = 11/4$ 。初始误差对后续结果的影响逐步减小, 但每轮仍有新扰动加入; 仅凭 $\rho < 1$ 不能断言带扰动误差趋于零。

式中的零次幂表示某项尚未经历缩放，即空积 1；当 $\rho = 0$ 时也按这一运算含义解释最后一项的系数。事实上，有限展开只用到 $\rho \geq 0$ 以保持不等号方向，不要求 $\rho < 1$ ；后一个条件与长期行为有关，不是展开有限步所必需的条件。

式 (1.7) 可以用数学归纳法证明：先核对 $t = 1$ 的基例，再假设结论对 t 成立并据此推出 $t + 1$ 时的结论。完整证明见第 1.4.3.3 节。

1.4 命题与证明

对象和计算规则写清之后，还需准确表达结论。例如，“每个样本各有一个正确参数”和“有一个参数对所有样本都正确”要求不同，不能用同一句含混的描述代替。我们需要说明结论覆盖哪些对象，参数能否随样本改变，以及要求的是存在一个答案还是恰有一个答案。逻辑把这些要求写成真假条件明确的陈述，证明则说明它们为何由已给条件推出。

1.4.1 命题与量词

1.4.1.1 逻辑运算与条件

“ F 有最小值”声称一件可以判断真假的事，“求 F 的最小值”则要求完成一项任务。逻辑要检查的是前一种陈述，称为命题 (proposition)：在给定的语境中具有真假值的陈述。带变量的表达式如 “ $x^2 \geq 0$ ” 还需要说明 x 的取值范围或添加量词，才成为完整命题。当 x 取实数时，这个不等式成立。若 x 取复数，则通常的实数大小关系不能直接用于 x^2 ，这一写法就没有给出可判断真假的条件。

命题 P 的否定记为 $\neg P$ 。两个命题的“且”“或”分别记为 $P \wedge Q$ 和 $P \vee Q$ 。数学中的“或”通常是可兼容的： P 和 Q 同时为真时， $P \vee Q$ 仍为真。若只允许恰有一个成立，需要明确写成异或条件。

蕴含 (implication) $P \Rightarrow Q$ 表示只要 P 为真， Q 就必须为真。这里 P 是 Q 的充分条件， Q 是 P 的必要条件。反向命题 $Q \Rightarrow P$ 需要单独证明。两向都成立时写作 $P \Leftrightarrow Q$ ，称为等价条件。

蕴含只禁止一种情形： P 为真而 Q 为假。 P 为假时，蕴含为真，但这不能用来断言 Q 本身为真。用“或”重写这个真假规则，便得到

$$P \Rightarrow Q \quad \Leftrightarrow \quad \neg P \vee Q. \quad (1.8)$$

此处外层双向箭头表示两种写法在所有真假组合下等价。例如，“若选候选 3，就必须选候选 1”允许不选 3，但不允许选了 3 却不选 1。这种规则不表达因果，也不声称两个候选必须一起选择。

以实数 x 为例, $x > 1$ 是 $x^2 > 1$ 的充分条件, 却不是必要条件, 因为 $x < -1$ 时也有 $x^2 > 1$ 。条件 $x \neq 0$ 是 $x^2 > 0$ 的充分必要条件。把充分条件误当作必要条件, 会排除本来可能成立的情形; 把必要条件误当作充分条件, 则可能把不合格对象当成解。

否定复合条件时, De Morgan 律说明怎样把否定移到每个子条件上:

$$\begin{aligned}\neg(P \wedge Q) &\iff (\neg P \vee \neg Q), \\ \neg(P \vee Q) &\iff (\neg P \wedge \neg Q).\end{aligned}\tag{1.9}$$

“并非两项都合格”只要求至少一项不合格; “两项中没有任何一项合格”则要求两项都不合格。用 1, 0 分别表示真、假, (P, Q) 取 $(0, 0), (0, 1), (1, 0), (1, 1)$ 时, 第一式两侧的真值都依次为 1, 1, 1, 0, 第二式都依次为 1, 0, 0, 0。这核对了全部四种解释, 而不是只举一个成立的例子。对成员条件使用同一规则, 也得到 $(A \cap B)^c = A^c \cup B^c$ 和 $(A \cup B)^c = A^c \cap B^c$, 其中补集必须相对于同一全集。

1.4.1.2 量词与依赖

找到一个零误差输入, 可以证明“有一个输入使误差为零”, 却还不足以证明“每个输入都使误差为零”。量词把结论需要覆盖多少对象写出来。全称量词 (universal quantifier) $\forall$ 表示“对每一个”, 存在量词 (existential quantifier) $\exists$ 表示“至少存在一个”。例如

$$\forall x \in \mathbb{R}, \quad x^2 \geq 0$$

是全称命题, 而

$$\exists x \in \mathbb{R}, \quad x^2 = 2$$

是存在命题。存在并不表示唯一; 要表达恰有一个对象满足条件, 可以写 $\exists! x \in X, P(x)$, 称为唯一存在 (unique existence)。它同时要求

$$\exists x \in X, \quad P(x) \wedge (\forall y \in X, P(y) \Rightarrow y = x).$$

例如 $x^2 = 2$ 在 $\mathbb{R}$ 上有两个解, 在 $(0, \infty)$ 上恰有一个解。唯一性必须相对于确定范围判断; “至多一个”也不等于“恰有一个”, 因为前者允许没有解。

否定量词时, 量词种类与内部命题同时改变:

$$\begin{aligned}\neg(\forall x \in X, P(x)) &\iff \exists x \in X, \neg P(x), \\ \neg(\exists x \in X, P(x)) &\iff \forall x \in X, \neg P(x).\end{aligned}$$

所以，要推翻“每个输入都满足性质 P ”，找到一个不满足的输入即可；要证明“没有输入满足 P ”，则必须排除所有输入。

考虑样本集合 $S = \{1, \dots, n\}$ 和参数集合 W ，令 $C(w, i)$ 表示参数 w 在第 i 个样本上预测正确。陈述

$$\exists w \in W, \forall i \in S, C(w, i) \quad (1.10)$$

要求找到同一个参数，使它对所有样本都正确。陈述

$$\forall i \in S, \exists w \in W, C(w, i) \quad (1.11)$$

却允许参数随样本改变，因而弱得多。若已经有一个适用于全部样本的参数，那么每个样本当然都能用它；反过来，各样本分别允许的参数集合可能互不相交，无法选出同一个参数。

示例 1.8 逐点可选不等于统一可选 令 $S = W = \{0, 1\}$ ，并规定 $C(w, i)$ 当且仅当 $w = i$ 。对每个 i ，选择 $w = i$ 即可，所以式 (1.11) 成立。但不存在一个 w 同时等于 0 和 1，所以式 (1.10) 不成立。

表 1.1 把这个例子的全部条件列出。读取式 (1.11) 时，每一列各自找到一个成立格即可；读取式 (1.10) 时，却必须找到一整行都成立。

参数	样本 0	样本 1	对量词的含义
$w = 0$	成立	不成立	不能覆盖全部样本
$w = 1$	不成立	成立	不能覆盖全部样本

表 1.1 例 1.8 的条件真值。每一列都有一个可选参数，却没有一行同时成立。

图 1.3 进一步把允许的选择顺序画出来。左侧知道 i 以后才选 w ，可以使用规则 $w(i) = i$ ；右侧必须先选 w ，后面的 i 仍要任意变化。量词表达的是信息依赖，不一定要现实中真的按这个时间顺序执行。

否定“统一可选”时，不能只说某个样本在某个参数下失败。逐层否定量词才得到准确陈述：

$$\begin{aligned} & \neg(\exists w \in W, \forall i \in S, C(w, i)) \\ \iff & \forall w \in W, \exists i \in S, \neg C(w, i). \end{aligned}$$

这里失败样本允许依赖于已给的 w 。在上例中，给定 w 后取 $i = 1 - w$ 就完成了否定。若要否定较弱的“逐点可选”，则需找到一个 i ，使所有 w 都失败；上例并不满足这一要求。这也解释了为什么一个失败配对不自动推翻带有多层量词的结论。




图 1.3 固定 $S = W = \{0, 1\}$ 和条件 $C(w, i) \Leftrightarrow (w = i)$, 只改变量词次序。左侧每个 i 分支分别选到合格的 w , 故 $\forall i \exists w C(w, i)$ 成立。右侧无论先选哪个 w , 其下两个 i 分支总有一个失败, 故 $\exists w \forall i C(w, i)$ 不成立。圆形标记表示条件成立, 叉形标记表示条件不成立; 右侧的虚线标出失败分支。

对空集合, 全称命题没有可检验的反例, 因此为真; 存在命题没有可选对象, 因此为假。这个约定称为空真 (vacuous truth)。应用中若“存在一个答案”本身就是要求, 应显式检查候选范围非空, 不能把空集合上的全称成立误读为已经找到答案。

1.4.2 公式与模型

表达式写定之后, 可以改变其中命题变量的真假值, 检查哪些解释遵守了规则。下面只考虑布尔变量的解释, 不引入更一般的一阶逻辑结构。

1.4.2.1 赋值与满足

把逻辑连接词作用于有限个命题变量, 便得到布尔公式 (Boolean formula)。变量各取什么值是一件事, 整个公式是否成立是另一件事; 为了检验规则, 需要把这两层对象明确区分。例如, 同一个公式 $z_1 \vee z_2$ 在 $(0, 0)$ 处为假, 在 $(1, 0)$ 处为真, 改变的是解释, 不是公式本身。

定义 1.9 赋值与公式的模型 给定命题变量 $z_1, \dots, z_n$, 赋值 (assignment) 是映射 $\nu : \{z_1, \dots, z_n\} \rightarrow \{0, 1\}$, 其中 0, 1 分别表示假、真。连接词的真值规则递归地确定公式的真值。若 Φ 在 ν 下为真, 称 ν 满足 (satisfy) Φ , 记作 $\nu \models \Phi$ 。满足公式 Φ 的赋值称为 Φ 的模型 (model), 即一种使规则成立的解释。全体模型组成集合 $\text{Mod}(\Phi)$ 。

这个“模型”只指逻辑公式的满足赋值, 不等同于后续章节中由参数描述的统计模型。

固定变量顺序以后, 赋值也可以用向量 $\mathbf{z} = (v(z_1), \dots, v(z_n)) \in \{0, 1\}^n$ 表示。下文的 $\Phi(\mathbf{z})$ 表示在这一赋值下求得的真假值, $v \models \Phi$ 则表示该真假值为真。在同一个变量集合上, 逻辑等价恰好对应模型集合相等。因此式 (1.9) 逐行真值相同, 也可以解释为两侧拥有完全相同的模型, 而不是只在某个选定赋值上碰巧成立。

假设一条选择规则要求“选候选 1 或不选候选 2”, 另一条规则要求“选候选 3 或选候选 4”。前者内部只需至少一项成立, 两条规则之间却要求同时成立。把“或”连接的一条规则与“且”连接的整组规则区分开, 就能按统一方式逐条检查。

定义 1.10 文字、子句与合取范式 一个文字 (literal) 是命题变量 z_i 或它的否定 $\neg z_i$; 一个子句 (clause) 是若干文字的析取, 只要其中至少一个文字为真, 该子句就为真。若公式由若干子句合取而成, 就称为合取范式 (conjunctive normal form, CNF), 它要求所有子句同时为真。

取四个候选 $V_0 = \{1, 2, 3, 4\}$, 用 z_i 表示“候选 i 被选择”, 真与假分别记作 1 与 0。要求候选 1 与 2 恰选一个, 候选 3 被选时必须选 1, 候选 4 被选时必须选 2 或 3。这些规则可以写成

$$\Phi(\mathbf{z}) = (z_1 \vee z_2) \wedge (\neg z_1 \vee \neg z_2) \wedge (\neg z_3 \vee z_1) \wedge (\neg z_4 \vee z_2 \vee z_3). \quad (1.12)$$

前两个子句共同表达 z_1, z_2 恰有一个为真; 第三个子句表达 $z_3 \Rightarrow z_1$; 第四个子句表达 $z_4 \Rightarrow (z_2 \vee z_3)$ 。后两项正是式 (1.8) 的使用: 把蕴含改写为子句以后, 可以用统一的“每个子句至少有一个真文字”检查整组规则。

例如, 赋值 $(1, 0, 0, 0)$ 使四个子句都为真; $(0, 1, 0, 1)$ 也如此。赋值 $(1, 1, 0, 0)$ 虽然使第一个子句为真, 却使第二个为假, 因此不满足整式。这一步是在核验给定赋值。给定公式后能否找到满足赋值, 是另一项求解任务, 留到第 2 章研究。

1.4.2.2 后承与冲突

一个赋值通过检查, 只说明规则有一种成立方式。要判断这些规则能否同时成立、是否对所有赋值都成立, 或者是否必然推出另一结论, 需要在赋值集合上使用不同量词。

定义 1.11 满足、可满足与永真 令 $\mathcal{V}$ 为给定 n 个命题变量的全部赋值映射组成的集合。一个赋值 $\nu \in \mathcal{V}$ 满足 Φ ，是对这个对象的判断；公式可满足 (satisfiable)，则是说至少存在一个满足赋值。对每个赋值都真的公式称为永真式 (tautology)。这两种公式性质分别写成

$$\text{可满足: } \exists \nu \in \mathcal{V}, \nu \models \Phi,$$

$$\text{永真: } \forall \nu \in \mathcal{V}, \nu \models \Phi.$$

没有满足赋值时称为不可满足，此时 $\text{Mod}(\Phi) = \emptyset$ 。

例如 $z_1 \vee \neg z_1$ 在 z_1 取真或假时都成立，所以是永真式； z_1 只在取真时成立，所以可满足但不是永真式； $z_1 \wedge \neg z_1$ 不可满足。就满足、可满足与永真三种判断而言，它们分别表示一个指定赋值属于 $\text{Mod}(\Phi)$ 、模型集合非空，以及模型集合等于整个 $\mathcal{V}$ 。本章说一组规则相容，是指它们的合取可满足，确有赋值能同时遵守全部规则。

找到一个满足赋值，可以确认这些规则能够同时成立。如果还想知道遵守这些规则是否必然使另一条结论成立，就需要检查每个满足赋值，而不只是刚找到的那一个。

定义 1.12 逻辑后承 在包含 Φ, Ψ 全部变量的共同赋值空间 $\mathcal{V}$ 中，若每个满足 Φ 的赋值也满足 Ψ ，记作

$$\Phi \models \Psi,$$

称 Ψ 是 Φ 的逻辑后承 (logical consequence)。等价地， $\text{Mod}(\Phi) \subseteq \text{Mod}(\Psi)$ 。

这表示规则已经强制推出 Ψ ，不表示某个求解器碰巧返回了满足 Ψ 的一个答案。例如，由式 (1.12) 可得

$$\Phi \models (z_3 \Rightarrow \neg z_2),$$

因为 z_3 推出 z_1 ，而 z_1 与 z_2 互斥。还可得

$$\Phi \wedge z_4 \wedge \neg z_2 \models z_3 \wedge z_1.$$

后一结论使用了额外观测 $z_4 = 1, z_2 = 0$ ，不能去掉这些条件后仍声称 $\Phi \models z_3$ 。用真变量的下标集合表示一个模型， $\Phi \wedge z_4 \wedge \neg z_2$ 只有 $\{1, 3, 4\}$ 这一个模型；原公式 Φ 则有五个模型：

$$\{1\}, \{1, 3\}, \{1, 3, 4\}, \{2\}, \{2, 4\}.$$

当 $z_1 = 1, z_2 = 0$ 时, (z_3, z_4) 只能为 $(0, 0), (1, 0), (1, 1)$; 当 $z_1 = 0, z_2 = 1$ 时, $z_3 = 0$ 而 z_4 任选。这既核对了数量, 也说明没有遗漏。原规则允许五个答案, 加入 $z_4 = 1, z_2 = 0$ 后只剩一个答案; 继续加入其他条件, 还可能让所有答案都被排除。下面考察这种冲突情形。

上述五个模型还说明, 可满足性不能决定应选择哪一个答案。 $\{1\}$ 与 $\{2, 4\}$ 都满足 Φ , 所以规则本身没有在二者之间作出选择。若再加入 z_2 与 z_3 , 即要求候选 2 和 3 都被选择, 公式变为不可满足: z_3 推出 z_1 , 却又要求互斥的 z_2 为真。冲突表示全部硬规则无法同时成立, 不等于程序尚未找到答案。

判断 $\Phi \models \Psi$ 可以转化为一次不可满足性检查:

$$\Phi \models \Psi \iff \Phi \wedge \neg \Psi \text{ 不可满足.} \quad (1.13)$$

若右侧可满足, 其模型就是一个满足 Φ 却违反 Ψ 的反例; 若右侧不可满足, 这样的反例不存在。用量词写, 这一步是 $\forall v \in \mathcal{V}, (v \models \Phi \Rightarrow v \models \Psi)$ 等价于不存在 $v \in \mathcal{V}$ 同时满足 Φ 与 $\neg \Psi$ 。这里 $v \models \Phi$ 的左侧是一个赋值, $\Phi \models \Psi$ 的左侧却是前提公式; 符号相同, 判断的对象不同。

定义还包含一个容易误读的边界: 若 Φ 本身不可满足, 则 $\text{Mod}(\Phi) = \emptyset$, 因而对任意 Ψ 都有 $\Phi \models \Psi$ 。这是前面介绍的空真: 由于没有满足前提的赋值, 也就没有反例赋值。因此, 这里的后承关系没有告诉我们在一个可行方案中 Ψ 会怎样成立。实际推理通常先检查 Φ 可满足, 再解释它的逻辑后承。

1.4.3 证明与反例

同一个结论可以用不同方式论证, 选择哪一种取决于已知条件能怎样发挥作用。本节用几个短例子比较这些方式: 蕴含命题可以从条件推到结论, 也可以排除结论不成立的情形; 存在命题可以给出满足条件的对象; 由整数索引的一族命题则可以利用相邻项之间的递推关系。反例承担另一项任务: 找出一个满足前提却违反结论的对象, 以说明某个全称命题不成立。

1.4.3.1 直接证明与间接证明

证明需要说明, 怎样从已给条件一步步得到结论。每一步都必须有依据; 若公式之间缺少这种推理联系, 即使各个公式本身正确, 也还没有证明所需结论。对蕴含命题 $P \Rightarrow Q$, 直接证明 (direct proof) 从 P 出发推出 Q ; 逆否证明 (proof by contraposition) 改证 $\neg Q \Rightarrow \neg P$, 即结论不成立时条件也不成立; 反证法 (proof by contradiction) 则暂时假设 P 成立而 Q 不成立, 再推出不可能同时成立的两项判断。在这里采用的经典逻辑中, 这些方式都能证明原蕴含, 但哪一种更清楚取决于条件怎样进入计算¹。

¹ R. L. Graham, D. E. Knuth, O. Patashnik, *Concrete Mathematics: A Foundation for Computer Science*, Addison-Wesley, 1994, 2nd ed.

示例 1.13 从条件直接推出结论 要证明“任意两个偶整数的和仍为偶数”，不能只计算 $2 + 4 = 6$ 。任取偶整数 a, b ，按定义存在整数 r, s 使 $a = 2r, b = 2s$ ，于是

$$a + b = 2(r + s).$$

$r + s$ 仍是整数，因此和满足偶数的定义。证明中 a, b 是任取的，没有增加“正数”或“大小有限”等限制，所以结论覆盖全部偶整数。

示例 1.14 通过逆否命题证明 对整数 n ，要证明“若 n^2 为偶数，则 n 为偶数”，可以改证它的逆否命题。整数不是偶数就是奇数，因此逆否命题可以直接写成“若 n 为奇数，则 n^2 为奇数”。设 $n = 2k + 1, k \in \mathbb{Z}$ ，有

$$n^2 = (2k + 1)^2 = 2(2k^2 + 2k) + 1.$$

这说明 n^2 为奇数，完成逆否证明。若改证“ n 为偶数则 n^2 为偶数”，虽然也正确，证明的却是原命题的逆命题，不能代替所需论证。

反证法也可以用来证明最小点的唯一性。假设有两个不同的最小点，如果能在允许范围内构造一个函数值更小的点，就会与这两个点已经取得最小值的假设矛盾。下面的中点条件正好提供了这种构造。

示例 1.15 用反证法排除两个最小点 设 $C \subseteq \mathbb{R}^d$ 满足：任取 $u, v \in C$ ，其中点 $(u + v)/2$ 仍属于 C 。若函数 $F : C \rightarrow \mathbb{R}$ 对任意不同的 $u, v \in C$ 都满足

$$F\left(\frac{u + v}{2}\right) < \frac{F(u) + F(v)}{2}, \quad (1.14)$$

那么 F 在 C 上至多有一个最小点。

中点条件提供了构造更小函数值的办法。反设 $u \neq v$ 都是最小点，并把共同的最小值记为 m 。由 C 对取中点封闭， $(u + v)/2 \in C$ 。再由式 (1.14)，

$$F\left(\frac{u + v}{2}\right) < \frac{m + m}{2} = m.$$

这与 m 是最小值矛盾，所以不可能存在两个不同的最小点。例如， $F(x) = x^2$ 在 $\mathbb{R}$ 上满足这一条件，因为

$$\frac{u^2 + v^2}{2} - \left(\frac{u + v}{2}\right)^2 = \frac{(u - v)^2}{4} > 0 \quad (u \neq v).$$

这里不是逐个检查所有候选点，而是说明任意两个不同的候选最小点都会与同一个条件冲突。

例 1.15 只证明“至多一个”，没有证明最小点存在。例如把同一个平方函数限制在 $(0, 1)$ 上，中点仍在定义域内，严格不等式仍成立，但任意 x 都有更好的 $x/2$ ，因此没有最小点。第 3 章将讨论极值存在的分析条件；第 4 章会把中点比较扩展到一般线段上的凸性，并讨论唯一性及求解方法。

1.4.3.2 构造性证明

存在命题 $\exists x \in X, P(x)$ 可以通过给出一个对象并核对条件来证明，这称为构造性证明 (constructive proof)。给出的对象既要属于规定范围，也要满足要求；写出一个候选公式本身还没有完成证明。

示例 1.16 构造两个实数之间的数 对任意 $a, b \in \mathbb{R}$ 且 $a < b$ ，取 $c = (a + b)/2$ 。实数对加法与除以非零数封闭，所以 $c \in \mathbb{R}$ 。由 $a < b$ 分别加上 a 与 b ，再除以正数 2，得到

$$a < \frac{a+b}{2} < b.$$

这同时检查了对象范围与两个严格不等式，证明存在 c 使 $a < c < b$ 。构造允许 c 依赖已给的 a, b ，对应 $\forall a \forall b \exists c$ 的量词次序，而不是选一个固定 c 供所有区间使用。

给出对象是一种存在性证明，但存在性证明还可以采用别的方式，例如假设对象不存在再推出矛盾。这种证明可能只确认对象存在，却未给出寻找它的算法。即使已经给出算法，也仍需证明算法能够终止，并且输出满足要求。后文谈“最优解存在”和“算法收敛”时，会分别承担这两项责任。

1.4.3.3 数学归纳法

逐步生成的序列通常有一条对所有步数适用的公式，但验算前几步不能保证以后仍然成立。数学归纳法 (mathematical induction) 把这项无限范围的要求化为一个起点和一条可反复使用的推进规则。对由整数 n 索引的一族命题 $P(n)$ ，先证明 $P(n_0)$ ，再证明对每个 $n \geq n_0$ ， $P(n)$ 蕴含 $P(n+1)$ 。这两步共同覆盖所有 $n \geq n_0$ ：基例使推进链条能够开始，归纳假设提供当前一步已经成立的条件，归纳步保证再前进一步也成立。推进步骤必须对任意 $n \geq n_0$ 有效，不能只检查 $P(1) \Rightarrow P(2)$ 。

回到式 (1.7)，它对每个整数 $t \geq 1$ 给出同一种误差界，正适合用归纳法验证。

式(1.7)的归纳证明. 当 $t = 1$ 时, 式(1.6)正是所需结论. 假设结论对 t 成立, 再使用一次递推式, 得到

$$\begin{aligned} e^{(t+1)} &\leq \rho e^{(t)} + \delta_t \\ &\leq \rho^{t+1} e^{(0)} + \sum_{s=0}^{t-1} \rho^{t-s} \delta_s + \delta_t \\ &= \rho^{t+1} e^{(0)} + \sum_{s=0}^t \rho^{t-s} \delta_s. \end{aligned}$$

第二行把归纳假设乘以 $\rho \geq 0$, 所以不等号方向不变; 第三行把新扰动写为 $s = t$ 的那一项, 其权重是 $\rho^0 = 1$. 这就是把 t 换成 $t + 1$ 后的式子. 基例与这一任意步推进共同证明结论对所有整数 $t \geq 1$ 成立. ■

同样的归纳结构还可以验证熟悉的有限和公式. 关键在于把第 $n + 1$ 项单独分离, 让剩下的 n 项恰好由归纳假设控制。

示例 1.17 用归纳法计算前 n 个正整数之和 对每个 $n \in \mathbb{N}$ 且 $n \geq 1$,

$$\sum_{i=1}^n i = \frac{n(n+1)}{2}.$$

当 $n = 1$ 时, 两边都等于 1. 假设公式对某个 $n \geq 1$ 成立, 则

$$\sum_{i=1}^{n+1} i = \left(\sum_{i=1}^n i \right) + (n+1) = \frac{n(n+1)}{2} + (n+1) = \frac{(n+1)(n+2)}{2}.$$

这正是 $n + 1$ 时的公式, 故结论对所有 $n \geq 1$ 成立. 例如 $n = 4$ 时, $1 + 2 + 3 + 4 = 10 = 4 \cdot 5 / 2$; 这个数值核对只是展示公式的含义, 覆盖所有正整数的是基例与归纳步共同构成的论证。

归纳假设只能用于已经假设的 $P(n)$, 不能把待证的 $P(n + 1)$ 换一种说法后当作依据. 若递推依赖前两个状态, 则归纳假设和基例也要覆盖相应数量的前项。

1.4.3.4 反例与边界

一个全称命题声称所有允许对象都满足某种性质, 所以一个合法反例就足以推翻它. 反例必须满足原命题的前提而违反结论; 若它同时违反前提, 只能说明例子不在讨论范围内。

示例 1.18 有下界但没有最小点 命题“目标函数有下界就一定达到最小值”是错误的。取

$$X = (0, 1), \quad f(x) = x.$$

$f(x) > 0$, 所以 0 是下界; 而对每个 $x \in (0, 1)$, $x/2$ 仍在 $(0, 1)$ 中且 $f(x/2) < f(x)$, 所以没有任何 x 达到最小值。这个例子满足“有下界”的前提, 却否定“达到最小值”的结论, 因而是合法反例。这个例子中的函数连续, 但函数值越小, 输入就越接近未包含在定义域中的端点 0。因此, 连续性在这个定义域上没有保证最小值存在。至于其他不闭的定义域上是否有最小点, 仍需根据具体函数判断。

量词还决定了否定结论的工作量。否定 $\forall x, P(x)$ 只需一个失败对象, 否定 $\exists x, P(x)$ 却要说明每个对象都失败。例 1.8 中, 每个固定 w 都有一个依赖于它的失败样本, 这否定了统一参数的存在; 只展示某个 w 预测失败, 尚未排除另一个 w 对所有样本都正确的可能。

反例也能区分相近概念。一个参数化不是单射, 说明参数未必可识别; 它不说明预测函数一定不能确定。一次迭代使目标下降, 说明当前步骤有效; 它不说明所有迭代都会收敛到全局最优。把结论限制到证据真正覆盖的对象, 是证明工作的一部分。

1.5 本章小结

回到章首的误差汇总问题。把式 (1.1) 取为 $d = 1, n = 2, \lambda = 0$, 两个样本是 $(x_1, y_1) = (1, 0)$ 、 $(x_2, y_2) = (1, 1)$ 。候选参数范围为 $\mathbb{R}$, 每个 w 表示函数 $f_w(x) = wx$, 样本索引 $i = 1, 2$ 则保留了两个相同输入及其不同输出要求。有限和给出的目标为

$$F(w) = \frac{1}{4}(w^2 + (w - 1)^2) = \frac{1}{2}\left(w - \frac{1}{2}\right)^2 + \frac{1}{8}.$$

平方非负, 且在 $w = 1/2$ 时为零, 故最小值为 $1/8$, 最小点集合为 $\{1/2\}$ 。这是通过配方完成的直接论证, 没有把“有下界”未经检查地当作“达到最小值”。

在同一个问题中, 每个样本都能各自找到零误差参数, 分别为 0 与 1; 但不存在同时满足两个要求的参数。这一区别由 $\forall i \exists w$ 与 $\exists w \forall i$ 表达。若进一步用递推生成候选 $w^{(i)}$, 初值与更新规则确定每个有限步结果, 却还不能保证这些结果趋于 $1/2$ 。对象范围、参数表示、样本编号、汇总运算和量词共同决定究竟在求什么、已经证明了什么。

同样的检查也适用于逻辑规则：一个模型是一个满足赋值，可满足性说明这样的赋值存在，后承则要求所有满足前提的赋值都遵守结论。要用反例否定保证，必须满足原前提并违反所声称的结论；要证明存在或唯一，也必须分别承担相应的论证责任。

本章已经说明怎样表示候选对象、计算结果和结论范围。接下来还需要研究：一个问题有多少候选对象，算法能否找到合格答案，以及无限次更新会怎样变化。第2章将研究计数、求解任务与程序条件；第3章将研究极限与极值存在的分析条件；第4章再比较候选质量与求解方法。把问题写准确之后，才能分别检查这些要求：有答案不等于能找到答案，能计算若干步也不等于最终会收敛。

计数与计算

从 n 个特征中选择一部分，每个特征都可以选或不选，共有 2^n 个子集。即使候选数量有限，把它们全部试一遍也可能很费时间。若还规定某些特征必须一起出现、某些不能同时出现，我们就要进一步判断哪些子集符合规则，并从合格子集中找到表现最好的一个。第1章已经给出了表达这些对象和规则的语言；本章继续回答：候选究竟有多少，能否找到答案，找到答案又需要多少计算。候选多并不意味着算法一定要逐个检查，因此计数与算法成本需要分别研究。

本章用二值选择说明它们的分工。对非负整数 n ，令

$$V = \{1, \dots, n\}, \quad \mathbf{z} = (z_i)_{i \in V} \in \{0, 1\}^n, \quad S(\mathbf{z}) = \{i \in V : z_i = 1\}.$$

赋值与子集是同一选择的两种表示。在贯穿例子中记 $V_0 = \{1, 2, 3, 4\}$ ，回用前章式 (1.12) 的四候选规则：候选 1 与 2 恰选一个；选 3 时必须选 1；选 4 时必须选 2 或 3。我们用这个例子检查怎样计数、怎样判断候选是否合法，以及怎样比较合法候选的收益。函数族的计数有相似的思路：先固定若干输入，再数候选函数能给出多少种不同的输出组合。这些计算之后，还要把问题推广到不同规模的输入，判断是否有同一个程序能正确处理每个输入，以及程序需要多少时间和存储空间。

2.1 候选空间的结构与计数

例如，先选特征 1 再选特征 3，与先选特征 3 再选特征 1，是否算作两种结果？若任务记录选择次序，它们是两个不同的有序选择；若任务只记录选中了哪些特征，它们都对应子集 $\{1, 3\}$ 。计数之前必须先确定什么算不同的结果。确定对象之后，我们再处理不同类别重叠造成的重复计数，分离总得分中来自各个子集的贡献，并计算函数在有限输入上能给出的输出组合。

2.1.1 有限结构的计数

确定了计数对象后，可以按它们的生成方式分组。互不相交的类别可以相加，分步选择可以相乘；若不同描述指向同一个对象，就必须扣除重复。若一个集合的得分包含了各个子集的贡献，还可以反过来问：怎样从总得分中分离出每个子集独有的贡献？这就是后面反演要解决的问题。

2.1.1.1 基本计数与增长尺度

第1章已经区分集合、序列和索引族。计数时还要确定哪些表示属于同一个结果，再研究规则改变后候选数量怎样变化。一个集合族 (set family) $\mathcal{F} \subseteq \mathcal{P}(V)$ 是一组允许讨论的子集。若不加任何限制， $\mathcal{F} = \mathcal{P}(V)$ 。加法计数要求类别互不相交：若 $A_1, \dots, A_r$ 两两不交，则 $|\bigcup_{i=1}^r A_i| = \sum_{i=1}^r |A_i|$ 。乘法计数要求每一步的可选数已经确定：无论前几步怎样选择，若第 i 步都有 n_i 种选择，完整选择序列就有 $\prod_{i=1}^r n_i$ 种；若可选数依赖前缀，须先逐分支计算再相加。对幂集，每个元素都有选与不选两种选择，故

$$|\mathcal{P}(V)| = 2^n. \quad (2.1)$$

前面的 (1, 3) 与 (3, 1) 说明，计数有序选择后，还要消除同一个子集的重复表示，才能得到无序选择的数量。设 n, k 为整数且 $0 \leq k \leq n$ 。从 n 个不同对象中依次取出 k 个且不放回，若顺序重要，可得到

$$P(n, k) = n(n-1) \cdots (n-k+1) = \frac{n!}{(n-k)!}$$

种排列。其中 $n! = 1 \cdot 2 \cdots n$ 称为阶乘，约定 $0! = 1$ 。若只关心选中了哪些对象，不关心次序，每个大小为 k 的子集被计算了 $k!$ 次，因此组合数为

$$\binom{n}{k} = \frac{n!}{k!(n-k)!}, \quad 0 \leq k \leq n. \quad (2.2)$$

规定 $\binom{n}{k} = 0$ 用于 $k < 0$ 或 $k > n$ ，可以统一许多边界公式。

把 n 个对象的子集按是否包含某个固定对象分组，可得 Pascal 恒等式

$$\binom{n}{k} = \binom{n-1}{k} + \binom{n-1}{k-1}.$$

第一项计算不包含固定对象的子集，第二项先包含该对象，再从其余 $n-1$ 个对象中选择 $k-1$ 个。这里按是否包含固定对象，把全部候选分成两个互不重叠、合起来又没有遗漏的类别，从而证明了恒等式。用这种分组计数来证明公式，称为组合证明。令 $a_{n,k} = \binom{n}{k}$ ，上述分组也给出了计算组合数的递推：

$$a_{n,k} = a_{n-1,k} + a_{n-1,k-1}, \quad n \geq 1, \quad (2.3)$$

其中 $a_{0,0} = 1$, 且 $k < 0$ 或 $k > n$ 时 $a_{n,k} = 0$ 。以 n 为行号, $n = 0, 1, 2, 3$ 的四行依次为 (1)、(1, 1)、(1, 2, 1) 和 (1, 3, 3, 1)。计算 $n = 4$ 这一行时得到 (1, 4, 6, 4, 1), 中间的 6 来自 $n = 3$ 这一行的 $3 + 3$ 。

二项式定理把组合数与代数展开连接起来:

$$(a + b)^n = \sum_{k=0}^n \binom{n}{k} a^k b^{n-k}. \quad (2.4)$$

选择展开式中的一项时, 需要从 n 个因子中挑出 k 个贡献 a , 其余贡献 b , 所以 $a^k b^{n-k}$ 前的系数正是 $\binom{n}{k}$ 。概率论中的二项分布和学习理论中的有限类计数都会复用这个关系。

回到四选二的例子, 排列数为 $P(4, 2) = 4 \times 3 = 12$; 每个二元子集被两个相反次序重复计算, 因此组合数为 $12/2 = 6$ 。

幂集的数量也可按子集大小分层计算, 再由二项式定理得到 $\sum_{k=0}^n \binom{n}{k} = (1 + 1)^n = 2^n$ 。逐个决定元素是否被选, 与先按子集大小分组, 是两种不同的计数过程; 它们计算的是同一批子集。

每个 $S \subseteq V$ 也确定一个有序二分划分 $(S, V \setminus S)$, 所以有序二分划分仍有 2^n 个。若两部分没有名称, $(S, V \setminus S)$ 与 $(V \setminus S, S)$ 表示同一个划分; 当 $n \geq 1$ 时没有子集等于自己的补集, 每个无序划分恰被计算两次, 数量为 2^{n-1} 。是否区分两侧决定了计数对象, 不能只看它们都把 V 分成两部分。这里允许某一部分为空; 若要求两部分都非空, 有序与无序数量应分别减为 $2^n - 2$ 与 $2^{n-1} - 1$ 。当 $n = 0$ 时, 交换两侧不会产生两个不同表示, 上述除以 2 的论证也不适用。

若只允许恰好选择 k 项, 集合族变为

$$\binom{V}{k} = \{S \subseteq V : |S| = k\}, \quad \left| \binom{V}{k} \right| = \binom{n}{k}.$$

若允许至多选择 k 项, 则数量为 $\sum_{j=0}^k \binom{n}{j}$ 。因此“候选总数有限”仍可能掩盖完全不同的增长规模: 固定 k 时, 该和关于 n 至多按 n^k 增长; k 随 n 线性增长时, 候选数却可能接近 2^n 。

规模增大时, 精确公式中的常数往往不是我们最关心的部分。例如, $3n+7$ 与 n 的数值不同, 却都按 n 的线性规模增长。为了比较这种增长速度, 需要一套忽略固定常数、保留主要规模的记号。候选数量与算法成本都可能随规模变化, 精确值不同的两个数列也可能具有同一增长尺度。这里的数列只表示按整数 n 编号的一组数, 不预先使用收敛理论。设 a_n 与 b_n 为实数序列, 且从某个位置开始 $b_n > 0$ 。若存在常数 $C > 0$ 和 n_0 , 使得

$$\forall n \geq n_0, \quad |a_n| \leq C b_n,$$

则记 $a_n = O(b_n)$ 。这表示 a_n 的绝对值最终被 b_n 的常数倍控制，常数 C 不随 n 改变。若对任意 $\varepsilon > 0$ ，都存在 n_ε 使

$$\forall n \geq n_\varepsilon, \quad |a_n| \leq \varepsilon b_n,$$

则记 $a_n = o(b_n)$ 。这要求最终能用任意小的正比例控制 a_n ，比一个固定常数倍的界更强。第3章会把它表述为比值趋于零，并用于函数的局部余项。

若 a_n 最终非负，存在 $c > 0, n_0$ 使所有 $n \geq n_0$ 满足 $a_n \geq cb_n$ ，就记 $a_n = \Omega(b_n)$ ；同时满足上界 $O(b_n)$ 和下界 $\Omega(b_n)$ 则记 $a_n = \Theta(b_n)$ ，表示同一数量级。例如 $3n + 7 = \Theta(n)$ ，而固定正整数 k 时 $\binom{n}{k} = \Theta(n^k)$ ：上界来自每个因子不超过 n ，下界可在 $n \geq 2k$ 时用每个因子至少 $n/2$ 得到。这里的常数可以依赖固定的 k 。

例如 $n = O(n)$ 、 $3n + 7 = O(n)$ 且 $\log n = o(n)$ 。但大 O 不是精确等式： $n = O(n^2)$ 也成立，只是界较松。写算法复杂度时还要说明被计数的操作、输入规模和计算模型；写统计误差时则要说明界是确定性的、期望意义的还是以高概率成立¹。

当序列还依赖维数 d 或其他规模时，也要说明哪些量允许进入隐含常数。例如，对每个固定 d 都有 $d/n = O(1/n)$ ，因为可以取 $C = d$ ；但若要求同一个 C 同时适用于任意 d ，这个界就不成立。因此，“关于 n 是某个速率”不等于该速率对维数一致。需要一致结论时，应把量词写成对所讨论的全部 d 使用同一组 C 与 n_0 ，或把 d 显式保留在界中。

对迭代序列，常用 t 而不是 n 表示步数。若目标 $F: \mathbb{R}^d \rightarrow \mathbb{R}$ 有有限下确界，记 $F^* = \inf_{\mathbf{w} \in \mathbb{R}^d} F(\mathbf{w})$ ；达到它的参照最小点（若存在）记为 $\mathbf{w}^*$ 。例如

$$F(\mathbf{w}^{(t)}) - F^* = O(1/t)$$

表示存在不随 t 变化的常数 C ，使充分大的 t 都满足 $F(\mathbf{w}^{(t)}) - F^* \leq C/t$ 。这个式子没有说明参数误差 $\|\mathbf{w}^{(t)} - \mathbf{w}^*\|_2$ 具有同样速率，也没有说明一次迭代的成本。比较算法时，必须固定误差对象和成本口径。

式(2.3)也可以按这个口径评估。逐行计算时，第 i 行的两个边界值为1，内部 $i-1$ 个值各需一次加法；因此生成第 n 行总共需要 $\sum_{i=1}^n (i-1) = n(n-1)/2$ 次加法。只保存上一行与当前行需要 $O(n)$ 个整数存储单元；也可以在同一数组内从右向左更新，避免覆盖本轮还要读取的旧值。若只求 $a_{n,k}$ 且 $1 \leq k \leq n$ ，可只更新至第 k 列，用 $O(nk)$ 次加法与 $O(k)$ 个整数单元；再利用 $\binom{n}{k} = \binom{n}{n-k}$ 减少列数。边界 $k=0$ 或 $k=n$ 时直接返回1。闭式公式、递推关系和计算过程由此承担不同作用：闭式便于分析规模，递推揭示分组结构，算法还必须说明求值顺序和资源。这里按整数加法次数计费，不把“大整数相加”当成一个比特操作；第2.3.1节会核对中间数值的位长。

¹ R. L. Graham, D. E. Knuth, O. Patashnik, *Concrete Mathematics: A Foundation for Computer Science*, Addison-Wesley, 1994, 2nd ed.

2.1.1.2 容斥原理与 Möbius 反演

要从全部赋值中扣除违反规则的赋值，可以先数出每条规则各有多少种违反方式。但一个赋值可能同时违反多条规则，直接相加就会重复计算。容斥原理 (inclusion-exclusion principle) 用交集项逐层校正这种重复。

定理 2.1 有限容斥原理 设 $A_1, \dots, A_m$ 是有限集合。则

$$\left| \bigcup_{i=1}^m A_i \right| = \sum_{\emptyset \neq I \subseteq \{1, \dots, m\}} (-1)^{|I|+1} \left| \bigcap_{i \in I} A_i \right|. \quad (2.5)$$

证明. 固定任意元素 x ，设它恰好属于 r 个集合。若 $r = 0$ ，它在等式两侧都没有贡献。若 $r \geq 1$ ，右侧从含有 x 的 r 个集合中选择非空索引集，给 x 计算的总系数为

$$\sum_{k=1}^r (-1)^{k+1} \binom{r}{k} = 1 - \sum_{k=0}^r (-1)^k \binom{r}{k} = 1 - (1-1)^r = 1.$$

所以并集中的每个元素在右侧恰好被计算一次，对所有 x 求和即得结论。 ■

回到 V_0 上的四个变量。把违反每一条规则的赋值分别组成集合：

$$\begin{aligned} A_1 &= \{\mathbf{z} : z_1 = z_2\}, \\ A_2 &= \{\mathbf{z} : z_3 = 1, z_1 = 0\}, \\ A_3 &= \{\mathbf{z} : z_4 = 1, z_2 = 0, z_3 = 0\}. \end{aligned}$$

它们分别表示候选 1 与 2 都选或都不选、选了 3 却没选 1，以及选了 4 却既没选 2 也没选 3。全部赋值有 16 个，并且

$$|A_1| = 8, \quad |A_2| = 4, \quad |A_3| = 2.$$

交集大小为

$$|A_1 \cap A_2| = 2, \quad |A_1 \cap A_3| = 1, \quad |A_2 \cap A_3| = |A_1 \cap A_2 \cap A_3| = 0.$$

由式 (2.5)，坏赋值共有 $8+4+2-2-1 = 11$ 个，因此可行赋值有 $16-11 = 5$ 个。它们对应

$$\mathcal{C}_0 = \{\{1\}, \{1, 3\}, \{1, 3, 4\}, \{2\}, \{2, 4\}\}. \quad (2.6)$$

这些集合恰是前章式 (1.12) 的全部模型。第 2.2.1.1 节将区分检查、判定与搜索对这批对象所要求的回答。

容斥处理的是若干集合的重叠。若两个特征单独使用各得 2 分，同时使用得 7 分，总分中除了两个单项的 4 分，还多出共同使用带来的 3 分。对更多特征，怎样从每个子集的总分中分离出这种新增贡献？子集之间的包含关系是完成这项计算的依据，也形成了前章定义的偏序。两个子集的交是包含于两者的最大子集，并则是包含两者的最小子集；这种带有交、并运算的子集偏序称为子集格。Möbius 反演（Möbius inversion）给出这一累加变换的逆。

定理 2.2 子集格上的 Möbius 反演 设 $g, h : \mathcal{P}(V) \rightarrow \mathbb{R}$ 满足

$$g(S) = \sum_{T \subseteq S} h(T) \quad \text{对每个 } S \subseteq V. \quad (2.7)$$

则

$$h(S) = \sum_{T \subseteq S} (-1)^{|S|-|T|} g(T). \quad (2.8)$$

反过来，由式 (2.8) 定义 h 也会恢复式 (2.7)。

证明. 把式 (2.7) 代入反演式右侧并交换有限求和次序，得到

$$\begin{aligned} \sum_{T \subseteq S} (-1)^{|S|-|T|} g(T) &= \sum_{T \subseteq S} (-1)^{|S|-|T|} \sum_{R \subseteq T} h(R) \\ &= \sum_{R \subseteq S} h(R) \sum_{T: R \subseteq T \subseteq S} (-1)^{|S|-|T|}. \end{aligned}$$

固定 R 后，中间集合 T 由 $S \setminus R$ 中哪些元素被加入决定。若 $q = |S \setminus R|$ ，内层和等于

$$\sum_{j=0}^q \binom{q}{j} (-1)^{q-j} = (1-1)^q.$$

它在 $R = S$ 时为 1，在 $R \neq S$ 时为 0，所以全部较小子集的贡献抵消，只留下 $h(S)$ 。反方向也可直接核对：由反演式定义 h 后，

$$\sum_{T \subseteq S} h(T) = \sum_{R \subseteq S} g(R) \sum_{T: R \subseteq T \subseteq S} (-1)^{|T|-|R|} = g(S).$$

内层仍是二项式和 $(1-1)^{|S \setminus R|}$ ，只有 $R = S$ 的项留下。 ■

更一般的有限偏序集把 $T \subseteq S$ 换成 $T \leq S$ 。其 Möbius 函数由 $\mu(S, S) = 1$ 以及 $\mu(T, S) = -\sum_{T \leq R < S} \mu(T, R)$ ($T < S$) 递归确定，不满足 $T \leq S$ 时取 $\mu(T, S) = 0$ 。反演系数不再只由 $|S| - |T|$ 决定。本章只使用子集格，此时递归解恰为 $\mu(T, S) = (-1)^{|S|-|T|}$ 。

在小集合 V_0 上，假设累计得分具有形式

$$g(S) = 2|S| + 3|\{1, 3\} \subseteq S| - |\{2, 4\} \subseteq S|.$$

每个单项贡献 2，组合 $\{1, 3\}$ 额外贡献 3，而组合 $\{2, 4\}$ 产生 -1 的交互。这里 $\mathbb{I}\{P\}$ 在条件 P 成立时取 1，否则取 0。四个元素共有 16 个子集。把每个子集的累计值与反演恢复的局部贡献并列，可以完整核对正向累加与反向消去：若只观察各子集的累计值，反演给出

S	$g(S)$	$h(S)$	S	$g(S)$	$h(S)$
$\emptyset$	0	0	$\{1, 2\}$	4	0
$\{1\}$	2	2	$\{1, 3\}$	7	3
$\{2\}$	2	2	$\{1, 4\}$	4	0
$\{3\}$	2	2	$\{2, 3\}$	4	0
$\{4\}$	2	2	$\{2, 4\}$	3	-1
$\{3, 4\}$	4	0	$\{1, 2, 3\}$	9	0
$\{1, 2, 4\}$	5	0	$\{1, 3, 4\}$	9	0
$\{2, 3, 4\}$	5	0	V_0	10	0

表 2.1 四元素子集格上的累计值与局部贡献。除四个单项、交互 $\{1, 3\}$ 和 $\{2, 4\}$ 外，其余局部贡献均为零。

$$h(\{i\}) = g(\{i\}) - g(\emptyset) = 2,$$

以及

$$h(\{1, 3\}) = g(\{1, 3\}) - g(\{1\}) - g(\{3\}) + g(\emptyset) = 3,$$

$$h(\{2, 4\}) = g(\{2, 4\}) - g(\{2\}) - g(\{4\}) + g(\emptyset) = -1.$$

其余大小至少为 2 的局部贡献均为零。反演并没有假设贡献为正；它只保证累计量与局部交互之间可以互相重构。

例如对 $S = \{1, 2, 3\}$ ，累计值为 $g(S) = 9$ ，三个二元子集的累计值依次为 4, 7, 4，三个单元素累计值之和为 6，且 $g(\emptyset) = 0$ 。反演确实给出

$$h(\{1, 2, 3\}) = 9 - (4 + 7 + 4) + 6 - 0 = 0.$$

把已经恢复的单项贡献 2, 2, 2 与二元贡献 3 重新相加，也得到 $g(\{1, 2, 3\}) = 9$ 。正向累加与反向消去由此可以在同一组数值上相互复核。

图 2.1 只保留 $\{1, 3\}$ 的四个子集，比较累计量与局部量。累计值 $g(\{1, 3\}) = 7$ 包括两个单项的 2 以及共同出现才增加的 3。反演从总分 7 中扣除单项已有的 4 分，得到这个组合独有的 3 分；累计值与局部贡献分别回答总共有多少分、其中多少分只来自共同出现。

容斥原理可以看成同一反演机制作用于指示函数。系数 $(-1)^{|S|-|T|}$ 使同一个较小子集的贡献在展开后正负抵消，只保留待恢复子集本身的贡献。后续图模型会把这一重构用于变量子集间的局部交互，再用图结构限制哪些交互允许出现。Möbius 反演本身只是一条有限集合恒等式，不会自动给出这些结构限制，也不保证所得局部项非负。




图 2.1 同一四元素教学构造在 $\{1, 3\}$ 的子集上的累计值与局部贡献。蓝柱为 g ，红柱为 h ；单项贡献各为 2，二元累计值 7 包含额外交互 3。图中四个子集的数据由正文解析式精确计算，没有省略影响这个二元交互的子集。

2.1.2 函数族的模式计数

前面数的是候选子集。比较一组预测函数时，直接数函数个数往往没有帮助，因为参数连续变化就可能产生无穷多个函数。可以改问：固定若干输入后，这些函数能给出多少种不同的预测组合？这里把一组输入上的输出组合称为标记模式。二值输出可以用集合计数，多类别输出要区分不同标签，实值输出则要指定比较阈值与误差尺度。数出这些模式，还不能直接知道需要多少训练样本或计算时间；那两项判断各有额外条件。

2.1.2.1 二值函数族的容量

参数可以无限变化，但固定有限个输入后，二值输出只有有限种组合。例如 $h_a(x) = \mathbb{I}\{x \geq a\}$ 的阈值 a 可取任意实数，但在输入 1, 2, 3 上，阈值落在 $(-\infty, 1]$ 、 $(1, 2]$ 、 $(2, 3]$ 与 $(3, \infty)$ 时分别产生 111, 011, 001, 000。无限多个不同函数在这三个点上只能被区分成四类。这里要数的是这四种模式，不是参数个数、函数个数，也不是某条约束下可行解的个数。把每种标记改写成一个子集后，有限集合计数就能刻画这种组合丰富度。给定输入 $x_1, \dots, x_m$ 和二值函数类 $\mathcal{H}$ ，每个 $h \in \mathcal{H}$ 确定

$$A_h = \{i \in \{1, \dots, m\} : h(x_i) = 1\}.$$

函数在这组输入上的标记向量与 A_h 一一对应，因此不同标记的数量就是集合族 $\{A_h : h \in \mathcal{H}\} \subseteq \mathcal{P}(\{1, \dots, m\})$ 的大小。式 (2.1) 随即给出上界 2^m 。不同输入组可能产生不同数量的模式；后面定义的生长函数将记录其中最大的数量。

这种区分也可表述为一个等价关系：若 h, g 在给定输入集 C 上处处相等，就记 $h \sim_C g$ 。每个等价类对应一个模式。只观察 C 上的输出时，我们会忽略函数在 C 之外的差异，却不声称这些函数在整个定义域上相同。

下列定义针对非空输入空间上的非空二值函数类 $\mathcal{H} \subseteq \{0, 1\}^{\mathcal{X}}$ ，不涉及抽样分布。把输入集 $C = \{x_1, \dots, x_m\}$ 按所列次序排列，收集所有函数在这些输入上的标记向量，得到限制类（restriction）。它只保留函数在当前输入集上的预测：

$$\mathcal{H}|_C = \{(h(x_1), \dots, h(x_m)) : h \in \mathcal{H}\}.$$

如果任意指定这些输入的 0, 1 标签，都能从函数类中找到一个函数全部实现，那么这组输入上就没有任何标签组合被函数类排除。下面把这种情形写成精确定义。

定义 2.3 打散 若对有限互异输入集 C 的每个二值标记 $(b_1, \dots, b_m)$ ，都存在 $h \in \mathcal{H}$ 满足 $h(x_i) = b_i$ 对全部 i 成立，就称 $\mathcal{H}$ 打散（shatter） C 。等价地， $\mathcal{H}|_C = \{0, 1\}^m$ 。

要比较不同函数类，可以继续问：最多能在多少个互异输入上实现全部二值模式？这个可打散规模的上限，由下面的 VC 维描述。

定义 2.4 VC 维 $\mathcal{H}$ 的 VC 维（Vapnik–Chervonenkis dimension）为

$$\text{VC}(\mathcal{H}) = \sup\{|C| : C \subseteq \mathcal{X}, |C| < \infty, C \text{ 被 } \mathcal{H} \text{ 打散}\}.$$

空集总能被非空函数类打散，所以维度可为 0；若任意大有限集都能被打散，则取值为 $+\infty$ 。

定义 2.5 生长函数 生长函数（growth function）记录 m 个输入上最多能区分多少模式。对整数 $m \geq 0$ ，定义

$$\Pi_{\mathcal{H}}(m) = \max_{x_1, \dots, x_m \in \mathcal{X}} |\{(h(x_1), \dots, h(x_m)) : h \in \mathcal{H}\}|. \quad (2.9)$$

$m = 0$ 时只有一个空标记，故 $\Pi_{\mathcal{H}}(0) = 1$ 。

VC 维记录可完整实现全部模式的最大输入集大小；生长函数记录任意给定输入数下最多实现多少模式。输入可重复的约定使有限输入空间上的式 (2.9) 也对全部 m 有定义；重复输入不会产生新的独立标记位。

对刚才的阈值类， m 个互异有序点把实数阈值分成 $m+1$ 个产生不同模式的范围，故 $\Pi_{\mathcal{H}}(m) = m+1$ 。单点的 0, 1 均可实现；若 $x_1 < x_2$ ，模式 10 要求 $x_1 \geq a > x_2$ ，不可能成立，所以 VC 维恰为 1。阈值函数能让任意

一个点取 0 或 1，却不能独立安排两个有序点的全部标签。这正是 VC 维为 1 所表达的限制。

这个表示还能直接计算受基数约束的函数族。令 $\mathcal{X}$ 为无限集，固定 $k \geq 0$ ，并设

$$\mathcal{H}_k = \{h_S : S \subseteq \mathcal{X}, |S| \leq k\}, \quad h_S(x) = \mathbb{I}\{x \in S\}.$$

对 m 个互异输入， $\mathcal{H}_k$ 能够实现的正类索引集合恰是所有大小不超过 k 的子集，因而

$$\Pi_{\mathcal{H}_k}(m) = \sum_{j=0}^{\min\{k, m\}} \binom{m}{j}.$$

固定 k 时，这个数量关于 m 至多按 m^k 增长；当 $k \geq m$ 时，它恢复为 2^m 。同一个幂集计数由此区分出多项式规模与指数规模。它仍只描述有限输入上的模式数，不直接给出统计误差界，也不保证能够高效找到实现某种标记的函数。

一个可逐项复核的例子是实数轴上的区间分类器。令 $x_1 < \dots < x_m$ 互异，函数 $h_{a,b}(x) = \mathbb{I}\{a \leq x \leq b\}$ 把落在某个闭区间内的输入标为 1。非空正类索引必为连续块 $\{i, i+1, \dots, j\}$ ，这样的块由 $1 \leq i \leq j \leq m$ 唯一确定；再加上空正类，可实现模式数恰为

$$1 + \sum_{i=1}^m (m - i + 1) = 1 + \frac{m(m+1)}{2}.$$

当 $m = 3$ 时，七个模式为 000, 100, 010, 001, 110, 011, 111，只有 101 无法实现。因此三个有序点不能被该函数类打散；两个点的四种模式都能实现。这个算例也说明，参数 a, b 取值无限多，并不意味着有限输入上的标记模式也有无限多个。

图 2.2 把阈值类与区间类放在一起比较。阈值类能打散一个点，却无法在两个有序点上实现 (1, 0)；区间类能在两个点上实现全部四种标记，三个点的 101 却要求包含两端而排除中点，违背连续块结构。后一张图 2.3 将这些具体模式换成模式数，显示数量怎样随输入点数增长。

图 2.3 把区间类与全部标记放在对数轴上比较。区间类的两个端点参数虽有无穷多种取值，有限输入上的模式数却仅按平方增长。计数相同也不表示函数类相同：当 $k = 2$ 时， $\mathcal{H}_k$ 的模式数同样为 $1 + m(m+1)/2$ ，但在三个点上它缺少 111，区间类却缺少 101。因此生长函数约束丰富程度，并不完整记录模式的结构。

区间例子的 VC 维为 2，而模式数恰好达到 $1 + m + \binom{m}{2}$ 。下面的计数界解释为何有限 VC 维足以限制全部输入上的增长，证明复用式 (2.3) 的“最后一个坐标”分组，但需要同时记录哪些旧模式能够接上两个不同标签。

假设空间	能打散的点集	多一个点时的反例
阈值 $VC = 1$	 (0) (1)	 (1,0) 无法实现
区间 $VC = 2$	 (0,0) (0,1) (1,0) (1,1)	 (1,0,1) 无法实现

图 2.2 阈值与单区间函数类的 VC 维。中列给出能够打散的输入和相应模式；右列给出多一个输入时无法实现的模式。实心点表示标签 1，空心点表示标签 0；黄色箭头表示阈值的正标签向右延续，黄色线段表示包含两个端点的区间也包含中间点。




图 2.3 有限输入上的二值模式数（精确计数教学图）。蓝实线为不受限制的 2^m ，红虚线为实数轴区间分类器的 $1 + m(m+1)/2$ 。纵轴使用对数刻度，红线是该具体类的精确计数；它也恰等于至多两个正类点的集合族计数，但两类实现的模式可以不同。

引理 2.6 Sauer–Shelah 引理 若 $d = \text{VC}(\mathcal{H}) < \infty$, 则对任意 $m \geq 0$,

$$\Pi_{\mathcal{H}}(m) \leq \sum_{j=0}^{\min\{d, m\}} \binom{m}{j}.$$

特别地, 当 $1 \leq d \leq m$ 时,

$$\Pi_{\mathcal{H}}(m) \leq \sum_{j=0}^d \binom{m}{j} \leq \left(\frac{em}{d}\right)^d. \quad (2.10)$$

证明. 固定 m 个输入上的有限模式族 $\mathcal{A} \subseteq \{0, 1\}^m$. 令 U 为删去末坐标后的所有模式, $V \subseteq U$ 为既能接 0 又能接 1 的模式, 则 $|\mathcal{A}| = |U| + |V|$. U 不能打散超过 d 个坐标. V 也不能打散 d 个坐标, 否则在这些坐标上任意赋值, 再把末坐标任意取 0 或 1, 就会由 $\mathcal{A}$ 打散 $d+1$ 个坐标, 产生矛盾.

对坐标数归纳. 零坐标时至多一个模式; $d=0$ 时也至多一个模式, 因为两个不同模式在某一坐标取值不同, 便会打散一个坐标. 对 $m, d \geq 1$, 归纳假设和上面的分组给出

$$|\mathcal{A}| \leq \sum_{j=0}^d \binom{m-1}{j} + \sum_{j=0}^{d-1} \binom{m-1}{j} = \sum_{j=0}^d \binom{m}{j},$$

其中超过坐标数的组合数约定为零. 重复输入不会增大模式数, 因此对全部输入组取最大值得到第一项结论.

当 $1 \leq d \leq m$ 时, 令 $a = d/m \in (0, 1]$. 对 $j \leq d$ 有 $a^d \leq a^j$, 故

$$a^d \sum_{j=0}^d \binom{m}{j} \leq \sum_{j=0}^d \binom{m}{j} a^j \leq (1+a)^m \leq e^{am} = e^d.$$

除以 a^d 便得到简化界. $d=0$ 时第一项界为 1, 不使用含 d 作分母的简化式. ■

引理只给出计数, 不直接给出概率保证, 也不保证能高效找到实现某种标记的函数. 固定 d 后, 计数上界至多按 m^d 增长; 具体类可以更慢. 要控制经验平均, 还需第 10 章中的抽样、可测性和集中条件.

2.1.2.2 多值函数族的容量

两个标签时, 每个点只有一种与当前标签不同的选择; 三个以上标签时, “改为另一个标签” 却不唯一. 例如两个输入上的六个模式

$$\mathcal{V} = \{(a, a), (a, b), (b, b), (b, c), (c, c), (c, a)\}$$

不能在两个输入处各固定两个标签，并实现这两对标签的全部四种组合；但从每个模式出发，都能只改变任一输入处的标签，得到另一个仍属于 $\mathcal{V}$ 的模式。“每个输入都能单独改变”与“预先指定的两种标签能任意组合”因此是不同要求，下面分别用不同的打散方式描述它们。

图 2.4 把这个有限例子放进两坐标表格。沿一行移动只改变第二个标签，沿一列移动只改变第一个标签；每个实心点都能沿两种方向找到另一个实心点，但没有任取两行两列形成的四个角同时占满。局部可改变与完整二选一组合由此可以直接区分。

第一坐标 \ 第二坐标	a	b	c
a	•	•	○
b	○	•	•
c	•	○	•

图 2.4 六模式族 $\mathcal{V}$ 的精确占位图。实心点表示模式属于该族，空心点表示缺失模式。每行每列恰有两个实心点，却没有完整的四角矩形；这不是两个标签的完整立方体。

本小节设 $\mathcal{H} \subseteq Y^X$ 非空， X, Y 为非空集合。有限点集中的输入均互异， $\mathcal{H}|_C$ 依固定的输入次序写成标记向量。以下维度均取可打散有限集大小的上确界，允许 0 与 $+\infty$ 。

一种比较方式是只问每个点的标签是否等于某个预先选好的基准。图打散 (graph shattering) 要求任意一种“匹配或不匹配”的安排都能实现，不匹配时采用的替代标签可以不同。

定义 2.7 图打散 若有限集 $C \subseteq X$ 存在 $f : C \rightarrow Y$ ，使每个 $B \subseteq C$ 都对应某个 $h_B \in \mathcal{H}$ ，满足

$$h_B(x) = f(x) \ (x \in B), \quad h_B(x) \neq f(x) \ (x \in C \setminus B),$$

则称 C 被 $\mathcal{H}$ 图打散。

定义 2.8 图维 图维 (graph dimension) 记录可独立安排这种匹配关系的最大点数。设 $\mathcal{C}_G$ 为所有被 $\mathcal{H}$ 图打散的有限输入集组成的集合，定义

$$d_G(\mathcal{H}) = \sup_{C \in \mathcal{C}_G} |C|.$$

示例 2.9 图维恰为 2 的有限函数类 令输入空间为 $\{x_1, x_2, x_3\}$, 函数类包含图 2.5 中的四个函数。以 $f(x_1) = a, f(x_2) = u$ 为基准, 四个函数在前两个输入上分别实现“两处都匹配、只匹配第一处、只匹配第二处、两处都不匹配”, 所以 $\{x_1, x_2\}$ 被图打散。第三个输入始终取 z , 任何包含 x_3 的集合都不能在该处独立安排匹配与不匹配; 输入空间又只有三个点, 故这个函数类的图维恰为 2。

参考预测: $f(x_1) = a, f(x_2) = u$

假设	x_1	x_2	x_3	与参考预测的关系
h_1	a	u	z	两处相同
h_2	b	u	z	仅第二处相同
h_3	a	v	z	仅第一处相同
h_4	c	w	z	两处不同

图 2.5 图打散与图维的有限例子。黄色框内两列相对于参考函数实现全部四种匹配或不匹配组合; 第三列固定为 z 。同一输入偏离基准时可以采用不同标签, 因而图打散没有预先固定唯一的替代标签。

若希望每次偏离时也使用预先指定的标签, 就得到更强的二选一要求。Natarajan 打散固定每个输入上的两个不同标签, 再要求所有逐点选择都能实现。

定义 2.10 Natarajan 打散与 Natarajan 维 设 $C = \{x_1, \dots, x_m\} \subseteq X$ 。若存在 $f, g : C \rightarrow Y$, 满足 $f(x) \neq g(x)$ 对所有 $x \in C$ 成立, 且对每个 $B \subseteq C$ 都存在 $h_B \in \mathcal{H}$ 使

$$h_B(x) = \begin{cases} f(x), & x \in B, \\ g(x), & x \in C \setminus B, \end{cases} \quad (2.11)$$

则称 C 被 $\mathcal{H}$ Natarajan 打散 (Natarajan shattering)。令 $\mathcal{C}_N$ 为所有被 $\mathcal{H}$ Natarajan 打散的有限输入集组成的集合, 定义 Natarajan 维 (Natarajan dimension)

$$d_N(\mathcal{H}) = \sup_{C \in \mathcal{C}_N} |C|.$$

示例 2.11 Natarajan 维恰为 2 的有限函数类 令输入空间为三封固定邮件 x_1, x_2, x_3 ，函数类只含图 2.6 中的四个函数。在 x_1 上固定标签对“正常、广告”，在 x_2 上固定“正常、诈骗”，四个函数实现两对标签的全部四种逐点选择，所以 $d_N \geq 2$ 。第三封邮件在四个函数下都预测为正常，任何包含 x_3 的输入集都不能在该处实现两个不同标签；输入空间只有三点，因此 $d_N \leq 2$ 。两项合起来得到 $d_N = 2$ 。




图 2.6 Natarajan 打散的四函数预测。每个框中的三项依次对应 x_1, x_2, x_3 ；横向只改变 x_1 ，纵向只改变 x_2 ，而 x_3 始终预测为正常。每个输入处的两个标签预先固定，四个函数实现全部二选一组合。

图打散只固定一个基准标签；偏离基准时具体采用哪个标签可以随子集改变。Natarajan 打散固定的标签对则不能随子集改变，但可以因输入点而异。前面的六模式例子不满足固定标签对的要求，却允许从每个模式出发单独改变任一输入的标签。为了描述这种选择自由，引入伪立方体 (pseudo-cube)：一组有限模式，其中每个模式都能只改变任一坐标，得到仍属于这组模式的另一个模式。

定义 2.12 伪立方体 有限非空集合 $V \subseteq Y^m$ 称为 m 维伪立方体，如果对每个 $v \in V$ 和每个 $i \in \{1, \dots, m\}$ ，都存在 $u \in V$ 满足 $u_i \neq v_i$ 且 $u_j = v_j$ 对所有 $j \neq i$ 成立。

定义 2.13 DS 维 若 m 个互异输入组成的有序点集 C 满足 $\mathcal{H}|_C$ 包含一个 m 维伪立方体，则称 C 被 DS 打散 (DS shattering)。DS 维 $d_{DS}(\mathcal{H})$ 定义为可被 DS 打散的有限点集大小的上确界；它记录最多有多少个输入，能够同时保留这种单独改变每处标签的自由。

伪立方体要求 V 有限、非空，并对其中每个模式的每个坐标都能找到邻居；只在一个起始模式附近有邻居并不够。邻居只改变一个坐标，却不要求整个族共享某两种标签。




图 2.7 六模式族 $\mathcal{V}$ 的逐坐标邻接。每个顶点是一种两输入预测；蓝实线只改变第一坐标，红虚线只改变第二坐标。每个顶点在两个方向上都有邻居，所以它构成二维伪立方体；图中没有固定两标签对形成的四角矩形，故其 DS 维为 2 而 Natarajan 维为 1。

维度	在有限输入上的要求
Natarajan 维	每点固定两个不同标签，全部 2^m 种逐点二选一组合均可实现
图维	每点固定一个基准标签，任意点集上匹配、其补集上不匹配的模式均可实现
DS 维	包含有限非空模式族，每个模式在任一坐标都可单独改变并仍留在族中

表 2.2 多类别组合维度的不同量词。图维中的“图”指标记相等关系的图打散，不是输入关系图的顶点数。




图 2.8 多分类维度关注的三种结构。Natarajan 维固定每个输入处的两个标签，图维固定一个基准标签并区分匹配与不匹配，DS 维考察预测向量之间只改变一个坐标的邻接。右栏只展示局部邻接方式；完整伪立方体还要求每个模式在每个坐标上都有邻居。

维度描述能够实现的局部选择, 生长函数则计算全部标记模式。要把两者联系起来, 先将式 (2.9) 中的二值函数类换成 $\mathcal{H} \subseteq Y^X$: 固定 m 个输入后, 计算 $\mathcal{H}$ 在这些输入上产生的不同标记向量, 再对全部输入组取最大值。有限标签时这个数量至多为 $|Y|^m$, 最大值存在; 允许重复输入的约定使有限输入空间也能讨论任意 m 。继续用 $\Pi_{\mathcal{H}}(m)$ 表示这个生长函数。Natarajan 维限制每个坐标上固定两标签的独立选择, 因而可以沿用 Sauer–Shelah 引理的计数思路。不过, 一个前缀现在可能接上两个以上标签, 递推必须计入所有不同标签对。

定理 2.14 有限标签的预测数目上界 设 $2 \leq |Y| = K < \infty$, $d = d_N(\mathcal{H}) < \infty$ 。记 $q = \binom{K}{2} = K(K-1)/2$ 为不同无序标签对的数目, 则对每个整数 $m \geq 0$,

$$\Pi_{\mathcal{H}}(m) \leq G_{d,K}(m) := \sum_{j=0}^{\min\{d,m\}} \binom{m}{j} q^j. \quad (2.12)$$

证明. 将有限非空模式族 $V \subseteq Y^m$ 视为坐标集 $\{1, \dots, m\}$ 上的函数类, 并设其 Natarajan 维至多为 d 。删去末坐标得到前缀族 $U \subseteq Y^{m-1}$ 。对 $u \in U$, 记它能够接上的末尾标签数为 $r(u) \geq 1$ 。这个前缀对 $|V|$ 贡献 $r(u)$, 对 $|U|$ 贡献 1; 多出的 $r(u) - 1$ 不超过它能够接上的标签对数 $\binom{r(u)}{2}$ 。对每个不同标签对 $\{a, b\}$, 令 $U_{a,b}$ 为既能接上 a 又能接上 b 的前缀族。对前缀求和可得

$$|V| \leq |U| + \sum_{\substack{\{a,b\} \subseteq Y \\ a \neq b}} |U_{a,b}|.$$

每个无序对在求和中只出现一次。 U 的 Natarajan 维至多为 d 。当 $d \geq 1$ 时, 每个非空 $U_{a,b}$ 的 Natarajan 维至多为 $d-1$: 否则它可以在某 d 个坐标上实现全部固定标签对的选择; 每个对应前缀又能接上 a 或 b , 使 V 在这 d 个坐标与末坐标上实现全部二元选择, 违反维度上界。空 $U_{a,b}$ 的计数贡献为零。

记 $M(m, d)$ 为 Natarajan 维至多 d 的非空模式族 $V \subseteq Y^m$ 能够达到的最大大小, 标签集 Y 保持固定。对 $m, d \geq 1$, 上述分组给出

$$M(m, d) \leq M(m-1, d) + qM(m-1, d-1).$$

零个坐标只有一个空模式, 故 $M(0, d) = 1$ 。维度为零时也至多有一个模式: 两个不同模式必在某坐标上取不同标签, 从而 Natarajan 打散一个坐

标。因此 $M(m, 0) = 1$ 。对 m 归纳，将两个较小问题的上界代入，并使用二项式递推关系，得到

$$\begin{aligned} M(m, d) &\leq \sum_{j=0}^d \binom{m-1}{j} q^j + q \sum_{j=0}^{d-1} \binom{m-1}{j} q^j \\ &= \sum_{j=0}^d \binom{m}{j} q^j, \end{aligned}$$

其中超出坐标数的组合数约定为零。任意输入组上的限制类，其 Natarajan 维不超过 $d_N(\mathcal{H})$ ；重复输入不能作为两个可独立选择的坐标。因此对输入组取最大值，得到式 (2.12)。 ■

当 $K = 2$ 时， $q = 1$ ，该求和式恢复为引理 2.6 的二值计数界。多出的 q^j 记录参与选择的 j 个坐标还可以使用不同标签对，而不表示一个具体函数类一定能达到上界。例如， $K = 3$ 、 $d = 1$ 、 $m = 4$ 时，上界为 $1 + 4 \times 3 = 13$ ，小于无约束的 $3^4 = 81$ 。固定 d, K 后，这个上界关于 m 至多按多项式增长；将模式数用于统计学习时，还需另加抽样与概率条件。

表 2.2 中的量词不同，却有一条共同的包含关系。固定两标签的完整选择产生伪立方体；伪立方体中的逐坐标邻居又能够实现相对某个基准模式的任意匹配与偏离。计数界还说明：标签数有限时，有限 Natarajan 维不允许图打散任意大的输入集，因为图打散需要指数多个不同模式。

定理 2.15 多分类维度的比较 对任意非空标签空间与非空函数类，有

$$d_N(\mathcal{H}) \leq d_{DS}(\mathcal{H}) \leq d_G(\mathcal{H}).$$

二标签时三者均等于 VC 维。若 $|Y| = K < \infty$ ，则 $d_N(\mathcal{H}) < \infty$ 也蕴含 $d_G(\mathcal{H}) < \infty$ 。

证明. 若 m 个输入被 Natarajan 打散，每个坐标的两个候选标签固定，全部 2^m 种选择组成一个有限非空模式族。任意模式都能只翻转任一坐标上的选择并仍留在族中，所以它是 m 维伪立方体，证明 $d_N \leq d_{DS}$ 。

若限制类包含 m 维伪立方体 V ，固定 $v \in V$ 作为基准。任取希望偏离基准的坐标集 $I \subseteq \{1, \dots, m\}$ ，逐个沿 I 中的坐标移动到邻居，每个坐标只移动一次。每一步仅改变当前坐标；之前改变的坐标保持不变， I 之外的坐标始终与 v 相同。因此最终模式恰在 I 上不等于 v ，在其补集上等于 v 。令 I 遍历所有子集就得到图打散，故 $d_{DS} \leq d_G$ 。

二标签时，偏离基准的标签唯一。图打散因此要求全部二元模式；伪立方体从任意模式逐坐标翻转也能到达全部二元模式。Natarajan 打散中的两标签正是整个标签集，所以三种维度都等于 VC 维。

若 $K = 1$ ，函数类在任何输入上只有一种标记，三种维度均为零。若 $2 \leq K < \infty$ 且 $d_N = d < \infty$ ，图打散 m 个输入至少需要 2^m 个不同模式。由定理 2.14，必有 $2^m \leq G_{d,K}(m)$ 。固定 d, K 后，右侧至多按多项式增长，左侧按指数增长，故能够被图打散的 m 有有限上界。 ■

前面的 $\mathcal{V}$ 每行和每列都恰有两个模式，所以构成二维伪立方体。它没有四角矩形，故不能 Natarajan 打散两个输入，而至少能打散一个，得到 $d_N = 1$ 。以 (a, a) 为基准， $(a, a), (a, b), (c, a), (b, b)$ 分别实现两个坐标上全匹配、仅第一坐标匹配、仅第二坐标匹配、均不匹配，因而 $d_G = 2$ ，并有 $d_{DS} = 2$ 。这是有限模式族的精确组合例子；它本身不构成不可学习性证明，相关统计条件由机器学习理论部分另行讨论。

三个维度的定义与 $d_N \leq d_{DS} \leq d_G$ 不要求 Y 有限，但式 (2.12) 确实需要有限标签数 K 。例如取无限 Y ，令 $\mathcal{H} = \{h_y : y \in Y\}$ ，其中 $h_y(x) = y$ 是常值函数。单点能在两个标签间任选，故三个维度都至少为 1；两个点上却只能输出 (y, y) ，既没有逐坐标邻居，也不能相对某个可实现基准只匹配一个点，所以三个维度都恰为 1。然而仅在一个输入上就有无限多个标签模式。有限维度因而不能在无限标签空间上直接推出有限模式数，更不能把含 K 的计数式无条件用于这种情形。

2.1.2.3 实值函数族的容量

前面的多类别维度把标签视为不同的符号。实值输出还具有大小关系，可以用阈值把数值变化转成高低模式；阈值必须在检验全部模式之前固定。例如，在两个输入处都以 20 为阈值，若“都高于、都低于、第一处高第二处低、第一处低第二处高”四种组合都可实现，就说明函数类能独立安排这两处输出在阈值的哪一侧。这里沿用固定有限输入与实现全部二元选择的组合结构，新增的是输出的大小关系及两侧的间隔要求。本小节取非空输入空间上的非空函数类 $\mathcal{F}$ ，有限输入 $x_1, \dots, x_m$ 互异；阈值可以随这些输入选定，却不能在看到待实现模式后重新选择。

这里离散化的是比较结果，不是实数值本身。仅看常值函数 $f_a(x) = a$ ($a \in \mathbb{R}$)，在单个输入上的输出集合已是整个 $\mathbb{R}$ ；固定阈值 $r = 0$ 后，输出才按高于、低于阈值分成两种严格模式，等于阈值的输出不充当任一侧的见证。多个输入使用各自固定的阈值，并不要求所有阈值相同。

定义 2.16 伪打散 设 $\mathcal{F} \subseteq \mathbb{R}^X$ 。有限集 $C = \{x_1, \dots, x_m\}$ 被 $\mathcal{F}$ 伪打散 (pseudo-shattering)，是指存在 $r_1, \dots, r_m \in \mathbb{R}$ ，使任意 $\mathbf{b} \in \{0, 1\}^m$ 都对应某个 $f_{\mathbf{b}} \in \mathcal{F}$ ，满足

$$b_i = 1 \Rightarrow f_{\mathbf{b}}(x_i) > r_i, \quad b_i = 0 \Rightarrow f_{\mathbf{b}}(x_i) < r_i \quad (1 \leq i \leq m).$$

定义 2.17 伪维 $\mathcal{F}$ 的伪维 (pseudo-dimension) 为 $\text{Pdim}(\mathcal{F}) = \sup\{|C| : C \text{ 为被 } \mathcal{F} \text{ 伪打散的有限集}\}$, 允许值为 $+\infty$; 没有非空被打散集合时值为 0。

二值类取阈值 $1/2$ 后, 伪打散与 VC 打散一致, 故其伪维等于 VC 维。实值类则仍缺少尺度: 20.001 和 19.999 已处于阈值两侧, 但若观测只记录四舍五入后的整数, 二者都会记成 20。胖打散 (fat-shattering) 要求每一侧再留出宽度 γ 的间隔。

定义 2.18 胖打散 给定 $\gamma > 0$, 若有限集 $C = \{x_1, \dots, x_m\}$ 存在固定阈值 $r_1, \dots, r_m$, 使任意 $\mathbf{b} \in \{0, 1\}^m$ 均对应 $f_{\mathbf{b}} \in \mathcal{F}$ 满足

$$b_i = 1 \Rightarrow f_{\mathbf{b}}(x_i) \geq r_i + \gamma, \quad b_i = 0 \Rightarrow f_{\mathbf{b}}(x_i) \leq r_i - \gamma, \quad (2.13)$$

则称 C 在尺度 γ 下被 $\mathcal{F}$ 胖打散。等价地, 以 $\sigma_i = 2b_i - 1$ 编码, 可写为

$$\sigma_i(f_{\sigma}(x_i) - r_i) \geq \gamma \quad (i = 1, \dots, m). \quad (2.14)$$

定义 2.19 胖打散维 尺度 γ 下的胖打散维 (fat-shattering dimension) 为 $\text{fat}_{\gamma}(\mathcal{F}) = \sup\{|C| : C \text{ 为在尺度 } \gamma \text{ 下被 } \mathcal{F} \text{ 胖打散的有限集}\}$ 。采用与伪维相同的 0 及 $+\infty$ 约定。

γ 增大时, 允许的模式只会减少, 胖打散维因此单调不增。伪维计算能否跨过阈值, 胖打散维进一步计算能否以规定幅度跨过阈值; 两者不能由参数个数直接代替。由于 $\gamma > 0$, 胖打散的每个见证都严格位于阈值对应的一侧, 故 $\text{fat}_{\gamma}(\mathcal{F}) \leq \text{Pdim}(\mathcal{F})$ 。反过来, 对一个被伪打散的固定有限集, 从每种二值模式各选一个见证函数, 这有限多个见证在有限多个输入处到阈值的距离均为正; 取这些距离的最小值为 γ , 就得到该集在某个正尺度下的胖打散。但这个 γ 依赖于输入集与所选见证, 不能据此声称任意预定尺度下两种维度相等。

幅度约束怎样进入这个维数, 可以用分块常值函数直接算出。

示例 2.20 分块常值函数的胖打散维 设非空集合 $A_1, \dots, A_m$ 构成 $\mathcal{X}$ 的一个划分, 并令

$$\mathcal{F}_B = \left\{ \sum_{j=1}^m a_j \mathbb{I}_{A_j} : |a_j| \leq B \right\}, \quad B > 0.$$

当 $0 < \gamma \leq B$ 时, 从每个 A_j 选一点并取阈值 $r_j = 0$; 对任意符号模式令 $a_j = \gamma \sigma_j$, 便能以间隔 γ 实现该模式, 所以这 m 个点被胖打散。反过来, 任意 $m+1$ 个点中至少两个落在同一个 A_j 内, 而类中每个函数在这两个点取值相同。若二者的阈值为 r 与 r' 且能够被胖打散, 模式 $(+1, -1)$ 要求 $r' - r \geq 2\gamma$, 模式 $(-1, +1)$ 又要求 $r - r' \geq 2\gamma$, 二者矛盾。因此该尺度下的胖打散维恰为 m 。当 $\gamma > B$ 时, 单点上的两个符号也要求函数值之差至少为 2γ , 超过允许区间 $[-B, B]$ 的宽度 $2B$, 故胖打散维为 0。分区数决定能独立调整多少处输出, 系数上界则决定输出能离阈值多远; 这个算例分别展示了这两项限制。

图 2.9 把例 2.20 中的两个分块写成输出平面。系数上界限定一个正方形; 胖打散还要求四种高低选择分别跨过固定阈值两侧的间隔。间隔增大到超过系数范围后, 候选函数仍然存在, 只是再也无法满足这些选择要求。




图 2.9 两个分块、 $B=1$ 与固定阈值 $r_1=r_2=0$ 的输出几何。灰框是函数类允许的 $(f(x_1), f(x_2)) \in [-1, 1]^2$; 浅黄区域要求两坐标分别离阈值至少 γ 。左图 $\gamma=0.5$ 的四种符号可由实心点实现; 右图 $\gamma=1.2$ 的空心点只标出要求的边界, 全部落在允许框之外, 因而不是类中的函数输出。图为解析教学构造。

上述组合维度回答的是函数类能否实现相应的标签安排。一个给定的标记或选择向量是否符合任务约束, 则需要下一节的逻辑规则。至于用有限多个代表函数在某种距离下逼近整类函数, 还要指定距离、误差尺度与有界性; 那是第 5 章的度量覆盖问题, 不能把这里的二元阈值模式数直接当作实值输出集合的大小。

2.2 候选空间上的约束与求解

知道有多少候选之后, 还要说明想得到什么答案。对于前面的四候选规则, 可以只问“有没有合法选择”, 也可以要求给出一个合法选择, 或进一步

要求找到收益最大的合法选择。这三种任务需要的输出不同。下面把各自的成功标准写清，再研究怎样构造答案和检查它与最优值的差距。

2.2.1 求解任务与答案质量

一个任务需要同时指定输入、允许返回的对象与成功标准。可行性只区分允许和不允许，不比较两个合法答案的优劣；增加目标函数后，最优与近似才有确定含义。

2.2.1.1 判定与搜索

第1章已定义公式的赋值、模型与逻辑后承。现在把规则作为程序的输入：检查一个给定赋值是否满足、回答有没有满足赋值，以及在有解时返回一个赋值，是三个不同的任务。前者只检验一个对象，后两者需要处理整个候选空间。

定义 2.21 硬约束 给定候选集合 Z 与必须满足的条件 $\phi_1, \dots, \phi_m$ ，硬约束（hard constraint）把可行集合限定为 $\mathcal{C} = \{\mathbf{z} \in Z : \phi_j(\mathbf{z}) \text{ 为真, 对所有 } j\}$ 。违反任意一条的对象不属于可行集合。

硬约束表达必须遵守的规则。判定（decision）只返回 $\mathcal{C}$ 是否非空；搜索（search）在非空时还须返回其中一个对象，在空集时报告无解。验证一个给定候选则只检查它是否属于 $\mathcal{C}$ ，候选本身是验证程序的输入。

布尔可满足性问题（Boolean satisfiability problem, SAT）的输入是一个布尔公式，输出只回答它是否存在满足赋值。输入限制为 CNF 时称为 CNF-SAT；进一步要求每个子句至多含三个文字时称为 3-SAT。若采用“恰含三个文字”的定义，可以重复文字补齐较短的非空子句，不改变可满足性；输入若含空子句，则公式立即不可满足。式 (1.12) 因此既是一个 CNF-SAT 实例，也是一个 3-SAT 实例。三者都回答“是否存在满足赋值”，但允许输入的公式形式不同；一个 SAT 实例未必已是 CNF-SAT 或 3-SAT 实例。

这里回用式 (1.12) 的四变量规则。它的模型可以写成 $S(\mathbf{z}) = \{i : z_i = 1\}$ ，全部模型恰组成式 (2.6) 的五个集合。容斥计算模型数量，SAT 只回答是否至少有一个；搜索程序还需实际输出见证。例如验证 $\mathbf{z} = (0, 1, 0, 1)$ 时，恰选一个、依赖与前提规则均成立，所以它是合法候选。判定程序对同一公式输出“是”，搜索程序可以返回这个四位向量，也可以返回另外四个模型之一；只交出“是”没有完成搜索。若给原公式再加入 z_1 与 z_2 两个必须为真的单子句，它们与“恰选一个”冲突，判定应输出“否”，搜索应报告无解，而不是返回一个违反规则的向量。由式 (1.13)，判断逻辑后承也可以转为查找满足前提却违反结论的赋值。两个任务在逻辑上等价，并没有告诉我们完成这次查找需要多少计算。

布尔规则也可以写成关于 $z_i \in \{0, 1\}$ 的代数约束。一个文字若为 z_i ，用数值 z_i 表示；若为 $\neg z_i$ ，用 $1 - z_i$ 表示。子句 $\ell_1 \vee \dots \vee \ell_r$ 恰好等价于

$$\sum_{j=1}^r v(\ell_j) \geq 1, \quad v(z_i) = z_i, \quad v(\neg z_i) = 1 - z_i. \quad (2.15)$$

因为左侧计算为真的文字个数，至少一个文字为真当且仅当该和不少于 1。

式 (1.12) 因而等价于

$$z_1 + z_2 = 1, \quad z_3 \leq z_1, \quad z_4 \leq z_2 + z_3, \quad \mathbf{z} \in \{0, 1\}^4. \quad (2.16)$$

第一条等式同时包含“至少一个”和“至多一个”。这些条件给出了前章所说的可行域，其中变量的零一取值条件必须保留。后续第 4 章会进一步研究可行域的几何结构与求解条件。

2.2.1.2 优化与近似

逻辑规则确定哪些集合允许，但通常仍会留下多个答案。要在这些答案之间作出选择，可以给每个可行集计算一个目标值，再找出目标最优者。如果精确求最优解代价太高，也可以要求返回一个可行解，并证明它的目标值与最优值相差多少。候选数量告诉我们要考虑多少种选择，可行性告诉我们哪些选择合法，目标值才告诉我们合法选择中哪个更好。

有些规则表达偏好而非绝对禁止，此时可以为违反规则设置非负代价。令 $r_j(\mathbf{z})$ 在第 j 条规则被违反时取 1，否则取 0。给这项违反设置权重 $\lambda_j \geq 0$ ，则可以最小化

$$c(\mathbf{z}) + \sum_{j=1}^m \lambda_j r_j(\mathbf{z}), \quad \mathbf{z} \in \{0, 1\}^n. \quad (2.17)$$

c 是任务本身的代价，第二项为规则冲突计分。权重有限时，足够大的任务收益可能抵消违反规则的代价，所以最优解仍可能违反这些规则，不能继续把它们当作必须成立的逻辑前提。

把 λ_j 取得很大也不能未经证明就等同于硬约束。若 c 的变化范围已知，例如 $|c(\mathbf{z}) - c(\mathbf{z}')| \leq B$ 对任意赋值成立，并且存在一个不违反任何软规则的赋值 $\mathbf{z}_0$ ，那么令每个 $\lambda_j > B$ 可以排除所有带违反项的全局最优解：任一违规赋值的目标值严格大于 $c(\mathbf{z}_0)$ 。若不存在零违反赋值、无法给出可用的 B ，或希望一族不同规模的实例共用罚权而 c 的振幅没有统一上界，或者只把部分权重取得较大，这个论证便不成立。若还为违规程度引入额外变量，同样要说明它们允许哪些原本被排除的赋值。这些做法各自改变了可行性或比较准则，使用时应明确允许返回什么答案。

规则确定集合族 $\mathcal{C} \subseteq \mathcal{P}(V)$ 后, 仍需用目标函数比较不同可行集合。一个有限组合优化问题可写成

$$\max_{S \in \mathcal{C}} F(S) \quad \text{或} \quad \min_{S \in \mathcal{C}} C(S). \quad (2.18)$$

由于 $\mathcal{C}$ 有限且非空, 实值目标一定达到最优值。这只回答存在性; 验证 $S \in \mathcal{C}$ 、计算 $F(S)$ 以及在不枚举全部候选的情况下找到最优解, 仍是不同任务。存在性的证明只需把 $\mathcal{C} = \{S_1, \dots, S_N\}$ 列成有限序列: 有限个实数 $F(S_1), \dots, F(S_N)$ 可逐项比较并取得最大值, 达到该值的某个 S_i 就是最优解。最小化结论可对 $-C$ 应用同一论证。若 $\mathcal{C} = \emptyset$, 则没有可行解; 若目标允许取无穷值, 也需另外说明所用的大小关系。因此“有限”“非空”和“实值”都是这个存在性结论的条件。

为了给前面的四候选规则增加一个可核对的目标, 设任务包含五项需求 $R = \{a, b, c, d, e\}$ 。每个候选 i 能够满足一部分需求, 用集合 Q_i 记录:

$$Q_1 = \{a, b\}, \quad Q_2 = \{b, c, d\}, \quad Q_3 = \{c, e\}, \quad Q_4 = \{d, e\}.$$

定义覆盖收益

$$F(S) = \left| \bigcup_{i \in S} Q_i \right|. \quad (2.19)$$

在 $\mathcal{C}_0$ 的五个可行集合上, 收益依次为 2, 4, 5, 3, 4, 所以 $\{1, 3, 4\}$ 达到最优值 5。这里最优解可以直接列举得到, 因为例子只有五个候选集合; 若 n 增大, 2^n 个赋值的枚举时间很快就会成为主要障碍。

如果不想遍历全部候选, 可以尝试每次只替换一个已选元素。但这样的局部改动未必能找到全局最优解。为单独检验这一点, 下面改用一个人工指定得分的小例子: 可行集合是 $V = \{1, 2, 3, 4\}$ 的所有二元子集, 并规定 $F(\{1, 2\}) = 1$ 、 $F(\{3, 4\}) = 3$, 其余二元子集的值均为 0。从 $\{1, 2\}$ 出发, 替换其中任一元素都会使目标降为 0, 所以它是一交换局部最优解; 全局最优解却是 $\{3, 4\}$ 。局部最优能否推出全局最优, 必须来自目标与可行域的额外结构。

当算法没有找到精确最优解时, 可以用目标值与最优值的差距评价它的输出。对非空集合 X 上的实值目标 f , 记 $f^* = \inf_{x \in X} f(x)$ 并假设它有限。给定 $\varepsilon > 0$, 若 $\hat{x} \in X$ 且

$$f(\hat{x}) \leq \inf_{x \in X} f(x) + \varepsilon, \quad (2.20)$$

则称 $\hat{x}$ 为 ε -近似最优解 (approximately optimal solution)。只要下确界有限, 这样的点对每个 $\varepsilon > 0$ 都存在; 否则 $f^* + \varepsilon$ 仍会是一个严格大于下确界的下界, 与下确界的定义矛盾。近似最优描述的是目标值差距, 不自动

保证 $\hat{x}$ 接近某个最小点。第 4 章会说明何种曲率条件能把目标误差换成参数距离。

式 (2.20) 要求下确界有限。若目标无下界，只能对每个有限阈值寻找更低的可行值，不能把 $-\infty$ 当作可达到的最小值，也不能用有限 ε 表达达到它的距离。

有限最大化问题常另用比例界比较质量。近似解的误差也要先约定口径，而且返回的集合仍须满足原来的规则。

定义 2.22 乘法近似与加法误差 设 S^* 最大化非负目标 F 于非空可行族 $\mathcal{C}$ 上，算法返回 $\hat{S} \in \mathcal{C}$ 。若 $0 \leq \alpha \leq 1$ 且 $F(\hat{S}) \geq \alpha F(S^*)$ ，称该输出达到 α 乘法近似；若 $\varepsilon \geq 0$ 且 $F(S^*) - F(\hat{S}) \leq \varepsilon$ ，则称其加法误差不超过 ε 。对非负目标 C 的最小化，乘法近似方向相反：用 $\rho \geq 1$ 要求 $C(\hat{S}) \leq \rho C(S^*)$ ；加法误差则要求 $C(\hat{S}) - C(S^*) \leq \varepsilon$ 。

例如覆盖任务的最优值为 5，返回 $\{2, 4\}$ 的收益为 4，便有 $4/5$ 的最大化比例及 1 的加法误差。若另一最小化任务的最优成本为 5、返回成本为 6，则其比例是 $6/5$ ，加法误差仍为 1，不应把 $4/5$ 一类小于 1 的保证照搬过去。当最优值为零时，非负最大化的比例条件只要求返回非负值，而最小化的有限乘法保证要求恰好返回零成本；用比值作相对误差还会遇到除零问题。目标可取负值时，乘法保证未必有原来的含义。加法误差不受目标加常数影响，但比例会变化：将收益 4, 5 同时减去 4 后得到 0, 1，比例从 $4/5$ 变为 0。因此平移目标虽保持最优解，也不能不加说明地保留原来的乘法近似结论。

若每个候选还有成本 $c_i \geq 0$ ，可以最大化 $F(S) - \sum_{i \in S} c_i$ ，也可以在预算 $\sum_{i \in S} c_i \leq B$ 下最大化 $F(S)$ 。这两个问题通常不等价：固定罚权隐含一种收益与成本交换率，预算约束则禁止所有超额集合。要断言对给定预算存在某个乘子并使两类问题的最优解对应，还需要额外条件。后续第 4 章会通过乘子与对偶工具讨论这种对应何时成立；本章的一般离散问题不保证这样的乘子存在，不能只凭形式相似互换两类问题。

2.2.2 求解与核验方法

得到一个可行候选与证明它足够好是两件事。贪心方法利用边际收益直接构造候选，松弛方法则通过扩大比较范围给出最优值的界。二者可以结合：一个可行解提供已经达到的值，一个有效界限制尚可能改善的空间。

2.2.2.1 贪心方法

前面的局部交换例子说明，仅凭当前得分高，还不能判断后续选择会怎样影响收益。覆盖任务多了一条可以利用的规律：已经覆盖的需求越多，同

一候选能够新增的需求就越少。我们把加入一个候选后增加的收益称为边际收益。这种规律将帮助我们评价逐步选择的算法，但所得保证还要依赖具体的选择约束。

定义 2.23 次模函数与边际收益 次模函数 (submodular function) 要求扩大已选择的集合后，再加入同一元素所得的边际收益不会增加；两次收益可以相等。正式地， $F : \mathcal{P}(V) \rightarrow \mathbb{R}$ 若对所有 $A \subseteq B \subseteq V$ 和 $e \in V \setminus B$ 满足

$$F(A \cup \{e\}) - F(A) \geq F(B \cup \{e\}) - F(B), \quad (2.21)$$

就称 F 为次模函数。记

$$\Delta(e | A) = F(A \cup \{e\}) - F(A)$$

后，式 (2.21) 表示 $\Delta(e | A) \geq \Delta(e | B)$ 。将式 (2.21) 的不等号反向，即定义超模函数。

新增收益随已选集合扩大而减小，并不意味着新增收益一定非负。要保证多选一个元素不会降低总收益，还需要另一项条件。

定义 2.24 集合函数的单调性 集合函数 $F : \mathcal{P}(V) \rightarrow \mathbb{R}$ 具有单调性 (monotonicity)，是指对任意 $A \subseteq B \subseteq V$ 都有 $F(A) \leq F(B)$ 。等价地，任意允许新增元素的边际收益都非负。

次模性不等于单调性。次模函数允许边际收益为负，只要求它随已选集合扩大而不增加。对于模函数 $F(S) = c + \sum_{i \in S} w_i$ ，加入元素 i 总是增加 w_i ，与已经选了哪些元素无关，因此同时是次模和超模函数，不论某些 w_i 是否为负。

互补收益给出次模性失效的最小反例。令 $G(S) = \mathbb{I}\{1, 3 \subseteq S\}$ 。把元素 3 加入空集的边际收益为 0，把它加入 $\{1\}$ 的边际收益却为 1。由于 $0 < 1$ ，加入 3 的收益随已选集合扩大而上升， G 不是次模函数。这个例子区分了“两个元素共同出现才有收益”的互补关系与覆盖函数中的替代关系。

前面的条件比较的是向两个嵌套集合加入同一个元素时的收益。也可以直接比较任意两个集合及其交、并的得分；下面的定理说明，两种比较要求等价。

定理 2.25 次模性的两个等价定义 集合函数 $F : \mathcal{P}(V) \rightarrow \mathbb{R}$ 满足边际收益递减式 (2.21), 当且仅当对任意 $A, B \subseteq V$ 有

$$F(A) + F(B) \geq F(A \cup B) + F(A \cap B). \quad (2.22)$$

证明. 先假设边际收益递减. 把 $A \setminus B$ 中的元素依次记为 $e_1, \dots, e_r$. 从 $A \cap B$ 加入这些元素得到 A , 从 B 加入同一序列得到 $A \cup B$. 在第 j 步, 前一条路径的当前集合包含于后一条路径的当前集合, 因此

$$F(A) - F(A \cap B) \geq F(A \cup B) - F(B).$$

移项即得式 (2.22)。

反过来, 取 $A \subseteq B$ 和 $e \notin B$, 将交并不等式用于 $A \cup \{e\}$ 与 B . 二者的交为 A , 并为 $B \cup \{e\}$, 故

$$F(A \cup \{e\}) + F(B) \geq F(B \cup \{e\}) + F(A).$$

移项便得到式 (2.21)。 ■

式 (2.19) 是次模性的典型来源。更一般地, 为每个需求 $r \in R$ 给定权重 $w_r \geq 0$, 定义

$$F(S) = \sum_{r \in \bigcup_{i \in S} Q_i} w_r. \quad (2.23)$$

定理 2.26 非负加权覆盖函数单调且次模 若所有 $w_r \geq 0$, 则式 (2.23) 定义的 F 是单调次模函数, 并满足 $F(\emptyset) = 0$ 。

证明. 空集合不覆盖任何需求, 所以 $F(\emptyset) = 0$. 若 $A \subseteq B$, 则 A 覆盖的需求也被 B 覆盖; 权重非负保证 $F(A) \leq F(B)$. 对 $A \subseteq B$ 和 $e \notin B$, 加入 e 的边际收益是

$$\Delta(e | A) = \sum_{r \in Q_e \setminus \bigcup_{i \in A} Q_i} w_r.$$

由于 $\bigcup_{i \in A} Q_i \subseteq \bigcup_{i \in B} Q_i$, 在 B 的基础上尚未覆盖的 Q_e 元素不会比在 A 的基础上更多。逐项使用 $w_r \geq 0$, 得到 $\Delta(e | A) \geq \Delta(e | B)$ 。 ■

在贯穿例子中, 候选 3 单独加入空集时新增 $\{c, e\}$, 边际收益为 2; 若已经选择 $\{2\}$, 需求 c 已经覆盖, 加入 3 只新增 e , 边际收益降为 1。这个计算展示了式 (2.21) 的一种情形, 但一般结论来自上面的集合包含证明, 而不是来自一个数值例子。

非负权重是单调性证明的实质条件。若某个被覆盖对象具有负权重，增加候选可能降低目标；函数是否仍次模要按具体形式检查。两个次模函数之和仍次模，非负倍数也保持次模性，但次模函数之差一般不次模。给覆盖收益减去逐项相加的成本，所得函数仍是次模函数，却可能失去单调性。

图 2.10 在同一个新增候选上核对边际递减：候选 3 覆盖 $\{c, e\}$ ，背景为空时新增两个需求；背景为 $\{2\}$ 时只新增 e ；背景进一步扩大为 $\{2, 4\}$ 时不再新增需求。这三个嵌套背景允许比较同一个元素的边际，而对不相包含的背景任意排出柱高次序，并不能验证次模性。




图 2.10 覆盖函数的有限教学构造。使用式 (2.19) 中的 Q_2, Q_3, Q_4 ，向 $\emptyset \subset \{2\} \subset \{2, 4\}$ 分别加入候选 3，覆盖增量为 2, 1, 0。柱高从零基线起画；图中只展示一个具体递减链，完整次模性仍由集合差证明。

次模性约束边际收益之间的关系，但只有与特定可行域和算法结合，才能得到求解保证²。下面只保留“至多选择 k 个元素”的约束，并要求 F 单调、次模且 $F(\emptyset) = 0$ 。最后这一条件称为归一化，即空选择的收益为零。对应的最大化问题是

$$\max_{S \subseteq V, |S| \leq k} F(S), \quad F(\emptyset) = 0.$$

贪心算法从 $S^{(0)} = \emptyset$ 开始，在第 t 步选择边际收益最大的元素

$$e^{(t)} \in \arg \max_{e \in V \setminus S^{(t)}} \Delta(e | S^{(t)}), \quad S^{(t+1)} = S^{(t)} \cup \{e^{(t)}\}.$$

平局可按固定顺序处理，使算法输出确定。算法在恰好选入 k 个不同元素后停止。 $k = 0$ 时只能返回空集； $k > |V|$ 时由单调性可直接返回 V ，无需继续选择。若一次 $F(S)$ 求值作为一个调用，直接实现每轮比较全部剩余元素，至多使用 $O(k|V|)$ 次目标调用；这个调用数并不包含实现 F 所需的内部运算。

² G. L. Nemhauser, L. A. Wolsey, M. L. Fisher, *An Analysis of Approximations for Maximizing Submodular Set Functions—I* In *Mathematical Programming*, 1978, vol. 14, pp. 265–294

示例 2.27 同一覆盖任务中的两步贪心 保留式 (2.19) 的四个覆盖集合, 但暂时只施加 $|S| \leq 2$, 不施加 $\mathcal{C}_0$ 的逻辑规则。空集上的边际收益为 2, 3, 2, 2, 所以第一步选 2, 覆盖 $\{b, c, d\}$ 。此时 1, 3, 4 的边际收益均为 1; 平局按编号选 1, 得到 $S^{(2)} = \{1, 2\}$, 收益为 4。六个二元集合的收益依次为 4, 4, 4, 4, 4, 3, 故这里贪心恰好最优。但 $\{1, 2\} \notin \mathcal{C}_0$: 同一个输出在基数任务中合法, 在原逻辑任务中不合法。

定理 2.28 单调次模最大化的贪心界 设 $1 \leq k \leq |V|$, F 归一化、单调且次模, S^* 是在 $|S| \leq k$ 下的最优解。上述贪心算法运行 k 步得到 $S^{(k)}$, 则

$$F(S^{(k)}) \geq \left(1 - \left(1 - \frac{1}{k}\right)^k\right) F(S^*) \geq (1 - e^{-1}) F(S^*). \quad (2.24)$$

证明. 固定第 t 步。由单调性、次模性以及逐个加入 $S^* \setminus S^{(t)}$ 中的元素,

$$\begin{aligned} F(S^*) - F(S^{(t)}) &\leq F(S^{(t)} \cup S^*) - F(S^{(t)}) \\ &\leq \sum_{e \in S^* \setminus S^{(t)}} \Delta(e | S^{(t)}). \end{aligned}$$

右侧至多有 k 项, 所以其中至少一项不小于 $[F(S^*) - F(S^{(t)})]/k$ 。若右侧没有元素, 则单调性已经给出 $F(S^{(t)}) \geq F(S^*)$, 剩余差距已经为零, 所需递推成立; 否则贪心选择的边际收益不小于上述某一项, 故

$$F(S^{(t+1)}) - F(S^{(t)}) \geq \frac{F(S^*) - F(S^{(t)})}{k}.$$

令剩余差距 $r^{(t)} = F(S^*) - F(S^{(t)})$, 便有 $r^{(t+1)} \leq (1 - 1/k)r^{(t)}$ 。由 $F(S^{(0)}) = 0$ 递推得到

$$r^{(k)} \leq \left(1 - \frac{1}{k}\right)^k F(S^*),$$

移项给出第一个不等式。再用初等指数不等式 $1 - u \leq e^{-u}$ ($0 \leq u \leq 1$), 得到 $(1 - 1/k)^k \leq e^{-1}$, 从而得到第二个不等式。■

上述保证不是精确最优性。另取六个需求与三个候选, 令 $Q_a = \{1, 2, 3, 4\}$ 、 $Q_b = \{1, 2, 5\}$ 、 $Q_c = \{3, 4, 6\}$, 仍至多选两个。贪心先选覆盖四个需求的 a , 再选 b 或 c , 总覆盖数为 5; 联合选择 $\{b, c\}$ 却能覆盖全部 6 个需求。每一步选择的当前边际都最大, 仍可能错过更好的组合。对 $k = 2$, 定理给出的保证为 $F(S^{(2)}) \geq (3/4)F(S^*)$, 此例的 $5/6$ 符合保证, 但不是 1。

定理 2.28 不能直接套到式 (2.6)。逻辑规则形成的 $\mathcal{C}_0$ 不是普通基数约束, 甚至不是向下封闭的: $\{1, 3\}$ 可行, 其子集 $\{3\}$ 却不可行。逐个加入当前边

际收益最大的元素可能在中途违反规则，或走入无法扩展到最优解的分支。其他约束下可以有不同的贪心、连续松弛或近似结果，但保证必须重新证明，不能只凭目标具有次模性。

2.2.2.2 松弛方法

当直接找最优候选困难时，可以先允许更多对象参与比较。松弛(relaxation)就是扩大可行范围，同时保留原候选上的目标值；扩大后的最优值可能更容易估计，并能限制原问题还可能改善多少。但“多允许了一些对象”和“已经找到松弛最优值”是两步不同的工作。

把每个可行集合 $S \in \mathcal{C}$ 写成指示向量 $\mathbf{z}(S) \in \{0, 1\}^n$ ，得到整数可行点集 Z 。若用 $P \subseteq [0, 1]^n$ 放宽候选范围，就要求 $Z \subseteq P$ 。在 P 上选定目标 G ，并让 $G(\mathbf{z}(S)) = F(S)$ 对全部原候选成立，则

$$F^* := \max_{S \in \mathcal{C}} F(S) \leq U^* := \sup_{\mathbf{z} \in P} G(\mathbf{z}). \quad (2.25)$$

原因只是原候选仍在扩大后的范围内；这里假设 $\mathcal{C}$ 有限、非空且 F 实值。用上确界而不直接写最大值，是因为一般的松弛问题未必达到最优值，也可能无界。若证明了有限的 $U \geq U^*$ ，就得到可用的原问题上界，不必一定求出松弛最优点。任何原可行候选 $\hat{S}$ 则给出下界 $L = F(\hat{S})$ 。于是

$$L \leq F^* \leq U, \quad 0 \leq F^* - F(\hat{S}) \leq U - L. \quad (2.26)$$

对非负目标且 $U > 0$ ，还可由 $F(\hat{S}) \geq (L/U)F^*$ 核验乘法质量。最小化时，松弛下确界提供下界 L ，原可行候选的值提供上界 U ； $U - L$ 仍控制加法误差，若 $L > 0$ ，则 U/L 给出最小化的乘法保证。

任意松弛候选 $\tilde{\mathbf{z}} \in P$ 只保证 $G(\tilde{\mathbf{z}}) \leq U^*$ ，没有理由使 $F^* \leq G(\tilde{\mathbf{z}})$ 成立。它既不是自动有效的上界，也未必是原可行解。即使数值求解器称该候选“接近最优”，也要有对应的误差证明，才能据此形成上界；仅有候选值或算法运行记录不足以核验原问题的质量。

原逻辑实例也能看到可行性上的区别。把式 (2.16) 中的 $\mathbf{z} \in \{0, 1\}^4$ 改为 $\mathbf{z} \in [0, 1]^4$ 后， $\tilde{\mathbf{z}} = (1/2, 1/2, 1/2, 1)$ 满足全部数值约束，却不是布尔赋值。按阈值 $1/2$ 把各坐标都取为 1，还会违反 $z_1 + z_2 = 1$ 。因此恢复原候选后必须重新检查原约束，不能把松弛可行直接当作逻辑可行。

上面的四变量例子说明了取整可能违反规则。为了进一步算清松弛最优值与原最优值的差别，考虑下面的两变量问题：

$$\max z_1 + z_2 \quad \text{s.t.} \quad 2z_1 + 2z_2 \leq 3, \quad z_1, z_2 \in \{0, 1\}. \quad (2.27)$$

三个整数可行点为 $(0,0), (1,0), (0,1)$ ，所以整数最优值为 1。放宽为 $0 \leq z_1, z_2 \leq 1$ 后，约束给出 $z_1 + z_2 \leq 3/2$ ，而 $(z_1, z_2) = (1, 1/2)$ 恰好达到 $3/2$ ，所以它是松弛最优值，确实是整数最优值的上界。对比之下，松弛可行点 $(1/4, 1/4)$ 的值为 $1/2$ ，小于整数最优值，不能作为上界。若把正坐标都取为 1，则得到 $(1,1)$ 并违反容量约束；若把 $1/2$ 向下取整，则恢复一个值为 1 的可行解。这个算例同时展示了松弛界、取整可行性与取整后目标值是三项不同检查。

图 2.11 把这几个点放回同一个可行区域。浅色区域中的点都满足松弛，但只有三个实心圆点属于原候选；约束保证整个松弛区域中的点都满足 $z_1 + z_2 \leq 3/2$ ，所以 $3/2$ 是上界。一个任意选出的区域内点只能给出自身的目标值，不能据此限制其他点的目标值。




图 2.11 式 (2.27) 的精确可行域。浅黄多边形为松弛范围 P ，蓝色实心圆点为原零一可行点，灰色方点的目标值仅为 $1/2$ ，红色空心圆点达到松弛最优值 $3/2$ ；右上角叉号为取整后不可行的 $(1,1)$ 。红色线段满足 $z_1 + z_2 = 3/2$ ，整个 P 都在该线的低值一侧。

仅使用 $L = 1, U = 3/2$ ，式 (2.26) 证明该候选的加法误差至多 $1/2$ 、乘法比例至少 $2/3$ 。这比本例的真实质量保守：原目标必为整数，所以 $F^* \leq 3/2$ 还能加强成 $F^* \leq 1$ ，从而证明候选恰好最优。若同一可行域改为最小化 $C(\mathbf{z}) = 2 - z_1 - z_2$ ，整数最优值仍为 1，松弛最优值变为 $1/2$ ，给出的是下界。任意松弛点 $(0,0)$ 的成本为 2，反而大于整数最优值，再次说明候选值不自动具有所需的界方向。

本小节只利用候选范围的包含关系建立界。松弛集合的几何结构如何影响最优值，以及取整后的可行性与目标误差怎样判断，将在后续第 4.5.1 节展开；目标具有次模性本身还不足以回答这些问题。

2.3 问题族的可计算性与复杂度

前节规定了什么结果算作合法答案，并给出了特定选择算法的质量保证。现在把考察对象换成整类输入及处理它们的统一程序：程序是否对规定输入正确终止，以及时间、空间和证书规模怎样随输入增长，是两类独立要求。每个输入都能写成有限字符串，仍不保证所有输入上的问题都能由同一个程序回答。例如，判断任意程序是否会结束，就会遇到后面要证明的不可判定性。即使可以穷举有限候选，也还要判断穷举所需的时间是否可以接受。

2.3.1 输入编码与计算模型

复杂度不是对象本身附带的标签，而是相对于输入编码、计算模型和所求输出定义的。固定有限字母表 $\Sigma = \{0, 1\}$ ，用 Σ^* 表示包括空串在内的所有有限比特串。程序、公式、整数与有限列表都须编码成这样的字符串，并能有效区分字段与检查语法。对有限变量问题，可以把 n 、CNF 公式、整数或有理数权重以及目标阈值写成有限比特串。输入长度记为 L ，它包括变量索引、子句、数值的二进制位数和分隔信息。未出现的变量可从可满足性判断中删除，出现的变量重新编号为 $1, \dots, n$ ，于是 n 受公式编码长度控制。若任务还要求输出未出现变量的值，就须把这部分输出长度另计；不能让一个很短的变量总数编码隐含不计费的巨大输出。

讨论 P 与 NP 时采用确定性多带图灵机的比特模型：机器只有有限个状态与有限种带符号，一步只读写常数个符号并移动读写头。运行时间计算步数，空间计算所占用的存储格数。这种模型使处理长整数的成本不能隐藏在一次任意精度运算中。讲解具体算法时也可先按数组访问或整数运算计数，但应注明那是另一层成本口径，并在需要时换算。长度为 b 的整数读取、比较与加法都可用 $O(b)$ 比特操作完成，直接逐位乘法则可用 $O(b^2)$ 比特操作完成；本章不依赖更快的大整数算法。

输入表示本身也会改变规模。若 n 个变量的规则用短公式隐式给出，枚举 2^n 个赋值是关于 n 的指数枚举；若输入已经显式列出全部 2^n 个 n 位候选，列表长度至少为 $n2^n$ 。逐字读取这张表关于列表长度是线性的，逐项核验还要加入每个候选的检验成本。两种说法并不冲突，因为它们采用了不同输入表示与规模变量。

数值大小不能替代编码长度。正整数 N 用二进制表示需要 $b = \lfloor \log_2 N \rfloor + 1$ 位，而执行 N 轮循环需要关于 b 指数级的轮数。例如 $N = 2^{20}$ 只需 21 位，逐一检查 $0, \dots, N - 1$ 却需要 1 048 576 轮。运行时间关于输入中的数值大小是多项式、关于二进制输入长度却未必是多项式的算法，称为伪多项式时间算法 (pseudo-polynomial-time algorithm)。若改用一元编码，把 N 写成 N 个标记，输入长度也会变为 N ；复杂度结论因编码而改变。

回查组合数的计算： $\binom{n}{j} \leq 2^n$ ，所以 Pascal 递推到第 n 行时，每个中间整数至多需要 $n+1$ 位。第 i 行的 $i-1$ 次加法每次可用 $O(i)$ 比特操作完成，因此逐行算法有 $O(n^3)$ 的比特时间上界，以及 $O(n^2)$ 的比特存储上界。这与前面的 $O(n^2)$ 次整数加法、 $O(n)$ 个整数单元并不矛盾。这些界都关于行号 n ，若输入仅是二进制编码的 n ，就不能称其为关于输入长度的多项式时间算法。特别是输出整行本身就需要 $n+1$ 个整数。

对于同一组选项和规则，程序要返回什么，会改变我们要求它完成的计算。常见的三种要求是：

- 搜索问题要求返回一个满足 Φ 的 $\mathbf{z}$ ；
- 优化问题要求返回目标最优的可行 $\mathbf{z}$ 或最优值；
- 判定问题只问是否存在满足 Φ 且 $F(S(\mathbf{z})) \geq T$ 的赋值，其中阈值 T 也属于输入。

无解时，搜索与优化接口都应显式报告无解；有解时，返回最优值和返回最优候选仍是不同输出规格。整数或有理数可使用精确有限编码；对一般实数答案，通常应把精度 ε 纳入输入并约定误差，而不是要求在有限步输出无限多个数位。

判定有时足以通过多次调用恢复候选，但需要能够固定部分变量并仍得到同类的合法实例。以 CNF 为例，先调用一次可满足性判定器；若回答“否”，报告无解。若回答“是”，尝试加入单子句 $\neg z_1$ 。回答“是”就固定 $z_1 = 0$ ，否则固定 $z_1 = 1$ 。随后在已固定前缀的公式上对 $z_2, \dots, z_n$ 重复此过程。每一步保持“当前前缀可以扩展为满足赋值”这一不变量：若取 0 无法扩展，而前一步保证存在扩展，则所有可用扩展必取 1。固定完 n 位后，唯一剩余赋值就满足原公式。总计至多 $n+1$ 次判定调用，加入的 n 个单子句只造成多项式长度增长。这种将问题的一部分固定后再调用同类判定器的方法称为自归约 (self-reduction)。

在四变量规则上，上述过程依次可固定 $z_1 = 0$ 、 $z_2 = 1$ 、 $z_3 = 0$ 、 $z_4 = 0$ ，得到候选 $\{2\}$ 。它完成搜索，却没有取得前面覆盖目标的最优值 5。若整数目标已知在 $[0, B]$ 内，并有判断“是否存在目标至少为 T 的可行解”的判定器，可以对 T 二分，用 $O(\log(B+1))$ 次调用确定最优值。要再恢复最优候选，判定器还须接受固定前缀与目标阈值的组合约束，然后才能重复上述恢复过程。调用成本、阈值位长、输出长度都要计入；对一般实值目标，没有已知分离精度就不能把整数二分过程直接照搬过去。

2.3.2 可计算性与可判定性

输入已经有有限编码，不代表关于它的问题总能由统一程序回答。这里暂不要求程序很快，只问它对哪些输入终止、终止时返回什么。有的程序能

最终确认“属于集合”的输入，却无法确认“不属于集合”的输入；有的程序能对两类输入都给出答案；还有的程序要计算一个具体的函数值。下面分别说明这些要求对应的停机条件。

2.3.2.1 可枚举、可判定与可计算

按顺序输出候选、回答某个输入是否属于集合，以及计算一个函数值，要求程序提供不同的信息。特别是等待某个候选出现时，暂时没有看到它，并不能给出“永远不会出现”的答案。下面都以有限字符串作为输入编码，以一个固定、有限描述的程序处理全部允许输入。

定义 2.29 可枚举、可判定与可计算 设 $A \subseteq \Sigma^*$ 。若存在程序不接收额外输入就依次输出 A 中全部字符串，称 A 为可枚举的 (computably enumerable)。这里要求程序只输出该集合中的对象，并最终输出其中每个对象；程序可以重复输出，也不必告诉我们某个尚未出现的对象以后是否会出现；空集允许由永不输出的程序枚举。集合 A 的成员判定若存在程序对每个 $x \in \Sigma^*$ 都在有限步内停机，并正确回答“是”或“否”，称为可判定的 (decidable)。若程序只保证在“是”实例上最终停机并接受，在“否”实例上不接受但可能永不停止，则称该问题半可判定的 (semidecidable)。全函数 $f: \Sigma^* \rightarrow \Sigma^*$ 若存在一个程序，对每个输入 x 都停机并输出 $f(x)$ ，就称 f 为可计算函数 (computable function)。部分函数 $f: D \rightarrow \Sigma^*$ ($D \subseteq \Sigma^*$) 可计算，是指存在程序恰在 $x \in D$ 时停机并输出 $f(x)$ ，在 $x \notin D$ 时不停机。

全函数对所有输入都有数学定义，部分函数只在 D 中有定义；这与程序在某次运行中是否已经算出值不是同一回事。仅承诺处理一个指定子集、对子集之外不作要求，是另一种带输入承诺的约定，并不等于上面要求域外不停止的部分函数模型。普通语法错误的编码可以统一判为“否”，使判定器在全部字符串上都有行为规定。成员判定可看作计算取值为 0 或 1 的特征函数，因此要求比只确认正例更强。

可枚举与半可判定其实等价。给定枚举程序，要半判定 $x \in A$ ，就逐个比较它输出的字符串；看到 x 便接受。若 $x \in A$ ，它最终会出现；若 $x \notin A$ ，程序不会错误接受。反方向不能逐个完整运行半判定器，因为在第一个负例上就可能永久等下去。把全部字符串按长度、同长度按字典序列为 $x_1, x_2, \dots$ ，采用交错运行：在第 t 轮，对前 t 个输入各从头模拟至多 t 步，输出所有在此范围内被接受的字符串。每轮只执行有限步；若 x_i 在 s 步后被接受，那么任意 $t \geq \max\{i, s\}$ 的轮次都会发现它。输出可以重复，但不漏正例，也不输出负例。这就构造了枚举程序。

可枚举仍不等于可判定。若 A 与补集 $\Sigma^* \setminus A$ 都可枚举，就交错模拟两个枚举器，一方每走一步再让另一方走一步，并比较其输出与待查字符串

x 。 x 必属于且只属于其中一方，因此有限时间后会被正确的一方确认，另一方不会误报。这样得到总会停机的判定程序。反过来，若 A 可判定，就可按顺序检查全部字符串，把“是”与“否”分别输出到两张清单，所以 A 及其补集都可枚举。只有正例可枚举时，等待尚未出现的对象无法证明它永远不会出现。

在明确的有限编码下，CNF 可满足性是可判定的。按字典序枚举全部 2^n 个赋值，每个赋值逐子句检查；找到满足赋值就回答“是”，全部检查完仍未找到则回答“否”。若公式有 m 个子句、总文字出现次数为 q ，直接实现需要 $O(2^n q)$ 次量级的文字检查，并存放当前 n 位赋值与输入公式。这里先处理空子句与空合取，再删除未出现的变量，使非平凡情形满足 $n \leq q$ 。若按可随机访问赋值数组的模型计费，检查一个文字为常数次访问；按比特机计费，地址处理还要展开，但仍能给出 2^n 乘以 L 的多项式的时间上界。这个算法很慢，但一定停机，所以它证明了可判定性。

“每个实例的候选集有限”还不足以独立构成上述证明。程序必须能从输入有效得到候选编码，能判定一个候选是否满足约束，并能知道枚举何时完成。若把一个不可计算实数或一个可能不停机的黑盒藏进“目标求值”，有限个候选也未必能被统一程序比较。可计算性要求的是对整族输入存在同一个有限描述的程序。

2.3.2.2 停机问题与不可判定性

有限变量问题在有效表示下可以穷举，但一般程序的行为并非总能判定。令

$$\text{HALT} = \{(P, x) : \text{程序 } P \text{ 在输入 } x \text{ 上最终停机}\}.$$

它是半可判定的：模拟 $P(x)$ ，若模拟停止就接受；若 $P(x)$ 永不停止，模拟也不会给出否定答案。下面的对角论证说明不存在总能判断停机与否的程序。

停机问题的不可判定性是可计算性理论的基本结论³。

定理 2.30 停机问题不可判定 HALT 不可判定。

证明. 反设存在判定程序 $H(P, x)$ ，它总会停机，并在 $P(x)$ 停机时返回 1，否则返回 0。据此构造程序 D ：输入一个程序编码 P ，先计算 $H(P, P)$ ；若结果为 1，就进入无限循环；若结果为 0，就立即停机。

现在把 D 自己的编码交给 D 。若 $H(D, D) = 1$ ，按照 D 的定义， $D(D)$ 进入无限循环，与 H 判断它会停机矛盾。若 $H(D, D) = 0$ ， $D(D)$ 立即停机，又与 H 判断它不停机矛盾。两种返回值都导致矛盾，所以这样的判定程序 H 不存在。 ■

³ A. M. Turing, *On Computable Numbers, with an Application to the Entscheidungsproblem* In *Proceedings of the London Mathematical Society*, 1937, vol. 42, no. 1, pp. 230–265

自输入 $D(D)$ 不是要求程序读取某个无限数学对象。 D 只有有限描述，因而其编码也是合法的有限字符串；假定的 H 已经承诺可以接收任意程序编码与任意输入，所以必须处理这个特例。对角构造正是利用了这项“对全部输入”的承诺。又因为 HALT 半可判定，其补集不能也半可判定，否则前面的交错程序便会判定 HALT，与定理矛盾。

定理 2.30 区分了“某次模拟尚未结束”和“已经证明不会结束”。前者是有限时刻的观察，后者要求排除所有未来时刻。不可判定也不等于每个具体程序都无法分析；许多程序可由终止度量、循环不变量或有限状态搜索证明停机。结论是不存在一个对任意程序和输入都正确的统一判定器。

2.3.3 复杂度与高效计算

已知存在正确终止的程序后，还需问它的成本怎样随输入增长。复杂度类别刻画整类实例的最坏资源要求；验证证书与归约则分别提供“给定答案是否易查”和“另一问题能否借助它求解”的比较方式。

2.3.3.1 运行时间与验证证书

可判定问题仍可能需要随输入长度急剧增长的资源。能统一快速求解，与只能快速核对给定答案，是不同的计算要求。

定义 2.31 复杂性类别 P 与 NP 若存在一个对所有实例都正确判定的确定性算法，其最坏运行时间由 L 的某个固定次数多项式控制，该判定问题属于复杂性类别 P。类别 NP 包含满足如下条件的判定问题 $\mathcal{L}$ ：存在多项式 p 和确定性验证程序 Ver，其运行时间关于 $|x| + |y|$ 为多项式，且每个输入 x 都满足

$$x \in \mathcal{L} \iff \exists y, |y| \leq p(|x|), \text{ Ver}(x, y) = 1.$$

其中 $|x|$ 是输入的比特长度， y 称为证书 (certificate)。

双向条件不仅要求每个“是”实例存在可接受的多项式长度证书，还要求“否”实例的所有这类证书都被拒绝。NP 名称中的“非确定性”指的是先猜测证书、再检查证书的计算模型。验证程序必须严格遵守上面的双向条件，不能用随机答错的方式接受一个“否”实例。确定性多项式算法的运行轨迹本身可作证书，所以 $P \subseteq NP$ 。目前并不知道这个包含是否严格；把 $P \neq NP$ 当作已经证明的事实，会超出这里可用的结论。

CNF 可满足性属于 NP。证书就是 n 位赋值 $\mathbf{z}$ ，在前面的变量编码约定下长度不超过输入长度的多项式。验证程序逐个检查子句，共做 q 次文字检查；在比特模型下也只需多项式时间。对四变量例子，验证给定赋值只需检查四个 CNF 子句中的九次文字出现；穷举则最多考察 16 个赋值。推

广到 n 个变量，前者仍只读给定候选，后者可能需要尝试 2^n 个候选。这是两个算法的成本比较，并不是所有求解算法都必须枚举的下界证明。

穷举证明可判定，短证书证明属于 NP，二者都没有给出多项式时间的求解算法。反过来，在前面已经证明的 CNF 自归约下，若有多项式时间判定器，就能以多项式次调用得到多项式时间搜索程序。因此判定与搜索的输出要求不同，却不意味着它们在每一种问题族上都有已知的复杂度分离。验证一个候选合法通常也不等于验证它最优：后者还须排除所有目标更好的候选，或取得足以排除它们的质量证书。

统计样本量与计算时间同样不能互相替代。一个候选族可能只需较少样本就能控制泛化误差，经验风险最小化却仍难以计算；也可能存在高效优化算法，但样本不足以区分多个预测规则。可计算学习还要求训练程序和输出的预测程序在约定输入上停机，高效学习进一步要求相应资源由规定参数的多项式控制。模式计数、样本量与运行时间需要各自的条件。

2.3.3.2 归约与困难性

仅见到 2^n 个候选还不足以证明求解困难，因为一个程序未必需要逐个检查。归约把另一个问题的全部实例有效变换到当前问题，用可复核的转换关系建立困难性。

定义 2.32 多项式时间多对一归约 若判定问题 A 的每个实例 x 都能在多项式时间内变换为判定问题 B 的实例 $f(x)$ ，并满足

$$x \in A \iff f(x) \in B,$$

就称 A 可多项式时间多对一归约 (polynomial-time many-one reduction) 到 B ，记作 $A \leq_p B$ 。

归约方向表示：若能高效解决 B ，就能先计算 $f(x)$ 再高效解决 A 。因此从已知困难问题归约到新问题，才能证明新问题至少同样困难；把方向写反不会得到这个结论。

定义 2.33 NP 困难与 NP 完全 一个判定问题若所有 NP 问题都可多项式时间归约到它，就称为 NP 困难 (NP-hard)；若它还属于 NP，就称为 NP 完全 (NP-complete)。

Cook-Levin 定理给出 SAT 是 NP 完全问题⁴。通过引入辅助变量，可以把一般公式在多项式时间内变成等可满足的 CNF 公式；再把长子句拆成由辅助变量连接的三文字子句，可以归约到 3-SAT。这里的“等可满足”只保证原公式有解当且仅当新公式有解，不要求辅助变量加入后两个公式

⁴S. A. Cook, *The Complexity of Theorem-Proving Procedures* In Proceedings of the Third Annual ACM Symposium on Theory of Computing, 1971, pp. 151–158

拥有相同的模型集合。结合 SAT 的 NP 完全性与上述归约, 可知 CNF-SAT 与 3-SAT 也都是 NP 完全问题。这里把结论作为复杂度理论的基准, 不展开对任意多项式时间验证计算的编码证明; 下面只证明与本章约束表示直接相关的归约。

定理 2.34 CNF 可满足性归约到零一线性可行性 给定任意 CNF 公式, 可以在关于公式长度的多项式时间内构造一组零一线性不等式, 使该公式可满足当且仅当这些不等式存在零一可行解。因此零一线性可行性是 NP 困难的; 当所有整数系数按二进制编码时, 它也属于 NP, 因而是 NP 完全的。

证明. 为每个命题变量建立 $z_i \in \{0, 1\}$ 。对每个子句 $C = \ell_1 \vee \dots \vee \ell_r$, 加入式 (2.15):

$$\sum_{j=1}^r v(\ell_j) \geq 1.$$

每个文字只产生一个变量项 z_i 或 $1 - z_i$ 。若使用保留文字出现的稀疏表达, 写出这些项只需线性次数的记录操作。若将同一变量的系数合并为标准线性不等式, 一条含 r 次文字出现的子句所产生的整数系数与常数项绝对值至多为 $r + 1$, 只需 $O(\log(r + 2))$ 位。排序、合并与整数运算均可在多项式时间内完成, 输出的比特长度也为输入长度的多项式, 因而这是所要求的多项式归约。空子句得到 $0 \geq 1$, 保留不可满足性; 没有子句时不加不等式, 保留可满足性。重复文字与同时出现的互补文字也仍按各次出现求和, 不影响真假等价关系。

若原公式有满足赋值, 把真假分别编码为 1, 0。每个子句至少一个文字为真, 对应不等式左侧至少为 1, 所以得到零一可行解。反过来, 任一零一可行解定义一个布尔赋值; 每条不等式左侧至少为 1, 说明相应子句至少一个文字为真, 故全部子句同时满足。两边可行性等价, 归约成立。

由 CNF 可满足性的 NP 困难性, 零一线性可行性 NP 困难。对其 NP 成员关系, 证书是一组零一变量值。若一行有 n 项、每个系数至多 b 位, 代入后累加所得整数只需 $O(b + \log(n + 1))$ 位; 验证者按二进制整数运算检查所有不等式, 所需时间关于输入和证书长度为多项式。 ■

定理 2.34 说明, 换成代数记号不会自动消除逻辑搜索的困难。它也没有声称每个零一线性实例都难: 式 (2.16) 只有四个变量, 可以立即求解; 某些约束矩阵或关系结构还允许专门的多项式算法。NP 完全描述的是一族问题在最坏情况下的归约地位, 不是每个实例的运行时间预测。

最坏情况复杂度也不同于一次实验运行时间。某个求解器在当前数据上很快, 可能来自实例结构、预处理或启发式分支顺序; 这不能证明问题属于 P。反过来, NP 完全性不排除小实例、特殊结构、参数受限情形或近

似目标能够高效求解。应说明保证针对精确解、近似值还是可行解，并列明依赖的参数与表示。

程序保证需要与数学答案的性质分开。回看式 (1.1)，要准确理解“求最小值”，还应分别检查答案是否存在、是否唯一、参数能否由观测辨认、是否有程序能求出，以及程序的资源消耗是否可以接受。

问题	需要回答的内容
存在性	是否有 $\mathbf{w}^*$ 真正达到 $\inf_{\mathbf{w}} F(\mathbf{w})$ 。
唯一性	达到最优值的参数是否只有一个。
可识别性	不同参数是否会产生相同的可观测预测或数据分布。
可计算性	是否有对规定输入终止并给出正确结果的统一程序，输出精度须明确。
高效性	在给定表示与精度下，时间和空间是否受所要求的资源界控制。

表 2.3 数学答案与程序的五类要求。可计算性只要求按约定终止并返回正确答案，高效性还约束资源；每一行都需要相应条件与论证。

这些问题彼此相关，却不能相互替代。一个有限非空候选集上的实值函数必定达到最小值，但若没有给出枚举候选或计算函数值的有效方式，存在性本身不提供实际算法。例 1.5 中的参数不可唯一识别，但乘积 ab 对应的预测函数仍可唯一确定。反过来，即使目标函数只有一个最小点，有限精度计算通常也只能返回近似值；能否精确到达该点，或能在多大误差内逼近它，需要单独的算法保证。

求解带正则项的最小二乘时，还要区别“找到了目标函数的最小点”与“恢复了产生数据的参数”。前一结论需要存在性与求解保证；即使最小点唯一，也没有自动得到后一结论。只有进一步声称参数能由观测唯一确定，或者算法恢复了真实参数时，才需要额外证明数据与参数化具有所需的可识别性。后续章节将在各自需要时分别给出这些条件。

2.4 本章小结

候选空间、求解任务和程序是三个不同的考察对象。精确计数与增长尺度说明结果数量怎样变化，容斥校正重叠，Möbius 反演恢复累计量中的局部贡献。函数族的限制类记录有限输入上可实现的标记；VC 维及多类别维度约束模式丰富度，实值函数还要固定阈值与间隔。这些容量结论不直接给出训练或求解算法的运行时间。

规则与目标共同规定答案。检查一个赋值、判定有解、构造见证与取得最优结果不能混用；子句的零一转换保持逻辑可行性，连续松弛和软代价则改变允许对象或比较准则。覆盖的边际递减配合单调性与基数约束，才能给出贪心质量界；松弛界还需另外检查取整后的可行性和目标误差。存在一个最佳候选，并不自动给出找到它的程序。

统一程序必须处理规定的整类输入。可枚举、可判定与可计算分别说明程序能提供什么回答，停机问题展示一般程序任务的不可判定边界；多项式时间、证书与归约则讨论资源和困难度。这些保证都须按输入表示、误差尺度与所求答案核对。连续候选与无限迭代的极限条件见第3章；关系结构对路径、分离和计算的影响见第9章。

测度与分析

设一次计算把误差从 1 降到 0.9，以后每次还会下降，我们能据此断言误差最终降到零吗？又如，用一系列函数近似一个函数，每个固定输入处的数值都越来越准确，按整个区域累计的积分也会越来越准确吗？有限步计算给出的结果，还不足以回答这两类问题。第 1 章建立了函数和条件的语言，第 2 章研究了有限选择与计算。本章进一步研究计算步数无限增加时的行为，以及哪些条件能够保证极限仍满足我们希望保留的性质。

这里以基础微积分和线性代数为基础。要判断对象是否接近，先要选定距离；要计算函数在一片区域中的总贡献，先要给区域分配权重。有了这两项约定，才能讨论序列的极限、迭代的误差、函数的局部变化与积分。当被研究的函数本身也在变化时，还要检查连续性、导数和积分能否传给极限函数。关键区别是：存在极限，并不意味着取极限可以与求导、积分交换次序。

3.1 集合的距离、权重与可测范围

沿用第 1 章的集合与映射语言，对于同一组观测，一方面可以比较两个观测的差异，另一方面可以汇总某些观测的贡献。前一个问题需要点与点之间的距离，后一个问题需要集合的权重。在连续空间中，还要明确哪些集合允许计算权重。下面分别建立这两项约定。

3.1.1 度量与邻域

实数可以用绝对值之差比较，但一个状态也可能是向量、一个函数或一组概率权重。此时先要指定什么差异算大、什么差异算小。度量把这种比较归纳为三条规则：零距离应能辨认同一个对象，比较不分先后，经由第三个点走两段，距离之和不能小于直接比较这两个点的距离。

定义 3.1 度量与度量空间 集合 X 上的度量 (metric) 是函数 $d : X \times X \rightarrow [0, \infty)$, 满足对任意 $x, y, z \in X$,

$$\begin{aligned} d(x, y) &= 0 \iff x = y, \\ d(x, y) &= d(y, x), \\ d(x, z) &\leq d(x, y) + d(y, z). \end{aligned}$$

带有度量的集合 (X, d) 称为度量空间 (metric space)。

欧氏空间使用 $d(\mathbf{x}, \mathbf{y}) = \|\mathbf{x} - \mathbf{y}\|_2$; 有限集合可以使用离散度量 $d(x, y) = \mathbb{I}\{x \neq y\}$ 。同一个集合选择不同度量, 可能改变何谓收敛以及函数是否连续; 不过, 有些度量只改变数值尺度, 例如 d 与 $2d$ 具有相同的收敛序列和连续映射。不能仅凭距离公式不同就断言这些性质不同。

为了把“与 x 相距不到 r ”的所有点收集起来, 可以直接用距离筛选一个集合。

定义 3.2 开球 在度量空间 (X, d) 中, 以 $x \in X$ 为中心、半径 $r > 0$ 的开球记为 $B(x, r) = \{y \in X : d(x, y) < r\}$ 。

开球把“离一个点足够近”写成集合。若 $V \subseteq X$ 包含某个 $B(x, r)$, 就称 V 是 x 的邻域; 邻域本身不必是开集。利用开球, 还可以判断一个集中的每个点周围, 是否都有一片仍属于该集合的小范围。

定义 3.3 开集与闭集 在度量空间 (X, d) 中, 集合 $U \subseteq X$ 若对每个 $x \in U$ 都存在 $r > 0$ 使 $B(x, r) \subseteq U$, 就称为开集 (open set); 集合 $C \subseteq X$ 若其补集 $X \setminus C$ 为开集, 就称为闭集 (closed set)。

开闭性总是相对于当前空间而言。例如 $[0, 1/2)$ 在 $\mathbb{R}$ 中不是开集, 但在子空间 $X = [0, 1]$ 中是开集: 此时开球是实轴开区间与 X 的交, 0 的一个小球不必包含负数。全集 X 和空集既开又闭; “不是开集”也不等于“就是闭集”, 实轴上的 $[0, 1)$ 便两者都不是。

同一集合上的距离选择也应随比较任务变化。在 $\mathbb{R}$ 上, 通常距离 $d_1(x, y) = |x - y|$ 把数值相近的状态看作接近, 离散距离 $d_2(x, y) = \mathbb{I}\{x \neq y\}$ 则只区分相同与不同。点 0 的 d_1 小球是区间, 而半径小于 1 的 d_2 球只有 $\{0\}$ 。在有限状态的概率向量 $\mathbf{p}, \mathbf{q}$ 之间, $\sum_i |p_i - q_i|$ 比较的是整组权重的差异; 在有界函数 $f, g : S \rightarrow \mathbb{R}$ 之间, $\sup_{x \in S} |f(x) - g(x)|$ 比较的是所有输入处的最大误差。后两种距离的点分别是概率向量和函数, 不能用一个未指定坐标的实数绝对值代替。后文会用 $1/n$ 和恒等映射具体核对 d_1, d_2 对收敛、连续性的不同判断。

有时比较规则只能看到对象的一部分，因而会把两个不同对象判为零距离。例如在 $\mathbb{R}^2$ 中只比较第一个坐标， $d(\mathbf{x}, \mathbf{y}) = |x_1 - y_1|$ 仍保留对称性和三角不等式，却无法区分 $(0, 0)$ 与 $(0, 1)$ 。后面的样本函数距离和半正定二次型都需要表达这种分辨力有限的比较。

定义 3.4 伪距离 集合 X 上的伪距离 (pseudometric, 也称伪度量) 是函数 $d : X \times X \rightarrow [0, \infty)$, 对所有 $x, y, z \in X$ 满足

$$d(x, x) = 0, \quad d(x, y) = d(y, x), \quad d(x, z) \leq d(x, y) + d(y, z).$$

它允许 $x \neq y$ 时仍有 $d(x, y) = 0$; 若进一步要求零距离蕴含 $x = y$, 就得到度量。

零距离并不意味着原始对象相等。若任务本来就不区分这些对象，可以把它们合并：定义 $x \sim y$ 当且仅当 $d(x, y) = 0$ 。自反性、对称性及三角不等式分别保证这是一项等价关系。在商集 $X/\sim = \{[x] : x \in X\}$ 上定义

$$\bar{d}([x], [y]) = d(x, y). \quad (3.1)$$

一个等价类可以用其中任意一个点代表。因此，上式只有在更换代表点后数值不变，才能定义等价类之间的距离。若 $x \sim x'$ 且 $y \sim y'$, 则 $d(x, y) \leq d(x, x') + d(x', y') + d(y', y) = d(x', y')$; 交换两对点又得反向不等式，故距离相等。其余度量条件直接继承，而且 $\bar{d}([x], [y]) = 0$ 恰好等价于 $[x] = [y]$, 所以商集确实成为度量空间。

在只看第一坐标的例子中， $[(a, b)] = \{(a, t) : t \in \mathbb{R}\}$ 是一条竖直直线；商空间中的点是这些直线，两点距离为第一坐标之差的绝对值。原空间丢失的第二坐标没有被恢复，而是被明确排除在比较对象之外。第 3.5 节中的函数等价类会回用这一做法。

3.1.2 测度与可测集

3.1.2.1 可测集合与赋权

前文用度量 $d(x, y)$ 比较两个点相距多远。若要累计一批点上的贡献，还需要知道这批点占多少权重，这一权重由集合 A 的测度 $\mu(A)$ 表示。两者处理不同对象，并不存在从距离公式直接得到唯一测度的通用规则。例如 $X = \{a, b\}$ 可以固定离散度量 $d(a, b) = 1$, 却分别使用计数权重 $(1, 1)$ 、非均匀权重 $(1, 2)$, 或归一化后的概率权重 $(1/3, 2/3)$ 。点列的收敛不因此改变，函数的积分却随权重改变。表 3.1 把这几个对象分开。

在连续空间中，不能只给每个点一个长度再逐点相加：单点的长度为零，区间的长度却可以为正。需要直接给适当的集合赋值，并要求把集合

对象	比较或汇总什么	$X = \{a, b\}$ 上的例子
度量 d	两点的距离	$d(a, b) = 1$
测度 μ	集合的权重	$\mu(\{a\}) = 1, \mu(\{b\}) = 2$
积分 $\int f d\mu$	函数值的加权总量	$f(a) + 2f(b)$
平均	总量除以总权重	$[f(a) + 2f(b)]/3$

表 3.1 距离与权重的不同职责。固定同一个距离仍可选择不同测度；只有总权重为 1 时，积分本身才直接是平均。

分割后，所有不重叠部分的大小能够相加。为此还要说清哪些集合可以计算权重。下面的集合族收集全部允许测量的集合，并要求取补集、合并可数多个可测集合后，结果仍能测量。

定义 3.5 σ 代数与可测空间 设 X 为集合。若子集族 $\mathcal{A} \subseteq \mathcal{P}(X)$ 满足

$$\begin{aligned} X &\in \mathcal{A}, \\ A \in \mathcal{A} &\implies X \setminus A \in \mathcal{A}, \\ A_1, A_2, \dots \in \mathcal{A} &\implies \bigcup_{n=1}^{\infty} A_n \in \mathcal{A}. \end{aligned}$$

则称 $\mathcal{A}$ 为 X 上的 σ 代数 (sigma-algebra)。二元组 $(X, \mathcal{A})$ 称为可测空间 (measurable space)， $\mathcal{A}$ 中的集合称为相对于 $\mathcal{A}$ 的可测集合 (measurable set)。

这些条件还蕴含 $\emptyset \in \mathcal{A}$ 及对可数交封闭。可数并与可数交足以描述后面序列产生的集合极限；这里没有要求任意多个可测集合的并仍可测。这样的范围既支持所需的极限运算，也为连续空间中的长度测度保留了适当的定义域。

选定可以测量的集合后，还需给它们分配相容的权重。相容的关键是：可数个互不重叠部分的总权重，应等于各部分权重之和。

定义 3.6 测度与测度空间 设 $(X, \mathcal{A})$ 为可测空间。映射 $\mu : \mathcal{A} \rightarrow [0, \infty]$ 若满足 $\mu(\emptyset) = 0$ ，并且对任意两两不交的 $A_1, A_2, \dots \in \mathcal{A}$ 有

$$\mu\left(\bigcup_{n=1}^{\infty} A_n\right) = \sum_{n=1}^{\infty} \mu(A_n).$$

则称 μ 为测度 (measure)。上述等式称为可数可加性，三元组 $(X, \mathcal{A}, \mu)$ 称为测度空间 (measure space)。

定义中的非负无穷和约定为有限部分和的上确界：

$$\sum_{n \geq 1} a_n = \sup_{N \geq 1} \sum_{n=1}^N a_n, \quad a_n \geq 0.$$

结果允许为 $+\infty$ 。这只回用第 1 章的有限和与上确界；第 3.2 节再研究一般级数的收敛。

实数上的 Lebesgue 测度把区间 (a, b) 赋值为 $b - a$ ；有限集合上的计数测度把集合赋值为元素个数；给有限点 x_i 分配质量 $w_i \geq 0$ 则得到 $\mu(A) = \sum_{i: x_i \in A} w_i$ 。因此有限加权和、通常的面积积分和后续的概率期望可以使用同一套记号¹。

¹ G. B. Folland, *Real Analysis: Modern Techniques and Their Applications*, Wiley, 1999, 2nd ed.

测度还保留集合包含的大小关系。若可测集合 $A \subseteq B$ ，把 B 分成不交的 A 与 $B \setminus A$ ，便有 $\mu(B) = \mu(A) + \mu(B \setminus A) \geq \mu(A)$ 。这项单调性将在零测集和集合极限中使用，不需要先定义函数积分。

度量与测度的常见联系发生在“哪些集合可测”这一层。度量先确定开集；我们可以要求所有开集都可测，再纳入取补集、取可数并所必需的集合，得到下面这族可测集合。

定义 3.7 Borel σ 代数 在度量空间 (X, d) 中，包含所有开集的最小 σ 代数记为 $\mathcal{B}(X)$ ，称为 Borel σ 代数 (Borel sigma-algebra)；其中的集合称为 Borel 集合。

“最小”指它包含在每个含有所有开集的 σ 代数中。实数上的开区间、闭区间和单点因而都是 Borel 集合。度量由此提供一族可测集合，却还没有指定它们的权重；在实数上，长度测度与把全部权重集中在某一点的测度，都可以定义在同一族 Borel 集合上。

3.1.2.2 集合极限与测度连续性

可测范围逐步扩大时，已经纳入的权重会不会在极限中丢失？记 $A_n \uparrow A$ 表示 $A_n \subseteq A_{n+1}$ 且 $A = \bigcup_n A_n$ ；记 $A_n \downarrow A$ 表示 $A_n \supseteq A_{n+1}$ 且 $A = \bigcap_n A_n$ 。这两种集合极限分别保留所有最终进入的点、所有始终没有被排除的点。可数可加性给出相应的测度连续性。以下各集合均属于可测集合族 $\mathcal{A}$ 。若 $A_1 \subseteq A_2 \subseteq \dots$ 且 $A = \bigcup_n A_n$ ，令 $B_1 = A_1$ 、 $B_n = A_n \setminus A_{n-1}$ ，则 B_n 两两不交且 $A_n = \bigcup_{k=1}^n B_k$ 。因此

$$\mu(A) = \sum_{k=1}^{\infty} \mu(B_k) = \lim_{n \rightarrow \infty} \mu(A_n).$$

这里的极限就是非负有限部分和的上确界, 允许为无穷, 不依赖函数积分。例如实轴上的 $A_n = (0, 1 - 1/n)$ 递增到 $(0, 1)$, 其长度 $1 - 1/n$ 也趋于 1; 端点 1 虽然从未进入集合, 但集合的极限仍有完整的单位长度。

若 $A_1 \supseteq A_2 \supseteq \dots$ 且 $\mu(A_1) < \infty$, 令 $A = \bigcap_n A_n$ 。对递增集合 $A_1 \setminus A_n$ 应用上一结论, 得到

$$\mu(A_1) - \mu(A) = \mu(A_1 \setminus A) = \lim_n \mu(A_1 \setminus A_n) = \mu(A_1) - \lim_n \mu(A_n).$$

所有相减项均有限, 故 $\mu(A) = \lim_n \mu(A_n)$ 。例如 $[0, 1/n] \downarrow \{0\}$ 且长度趋于 0。递减情形需要 $\mu(A_1) < \infty$: 若每个 A_n 的测度都为无穷, 就不能通过“无穷减无穷”得到结论。例如 Lebesgue 测度下 $A_n = (n, \infty)$ 递减到空集, 但每个 A_n 的测度仍为无穷。

3.1.2.3 零测例外与测度完备性

测度允许某些非空集合的权重为零。讨论积分和函数极限时, 这些集合上的例外往往不影响总量; “几乎处处”就是把这种可忽略性说清楚。

定义 3.8 零测集与几乎处处 在测度空间 $(X, \mathcal{A}, \mu)$ 中, 若 $N \in \mathcal{A}$ 且 $\mu(N) = 0$, 称 N 为零测集 (null set)。若存在这样的 N , 使某性质对每个 $x \in X \setminus N$ 成立, 称该性质 μ -几乎处处 (almost everywhere, 简写为 a.e.) 成立。

这里不要求例外集合为空, 而是要求它包含在一个可测的零测集中。换用另一个测度后, 原来的例外可能不再可忽略。例如单点在长度测度下为零, 在计数测度下却有质量 1。

还会遇到另一项要求: 一个集合既然没有权重, 它的任何子集也应能被赋予零权重。这项要求并非由可数可加性自动保证, 因此需要单独说明。

定义 3.9 完备测度空间 若测度空间 $(X, \mathcal{A}, \mu)$ 中每个零测集 N 的任意子集 $E \subseteq N$ 都属于 $\mathcal{A}$, 称该测度空间完备。此时由测度的单调性还有 $\mu(E) = 0$ 。

把可测零测集的所有子集加入原 σ 代数, 并相应扩展测度, 称为测度空间的完备化。具体地, 令

$$\overline{\mathcal{A}} = \left\{ A \cup E : \begin{array}{l} A, N \in \mathcal{A}, \quad \mu(N) = 0, \\ E \subseteq N \end{array} \right\},$$

$$\bar{\mu}(A \cup E) = \mu(A).$$

若同一集合还有表示 $A' \cup E'$, 则 $A \setminus A'$ 和 $A' \setminus A$ 都包含在一个可测零测集中; 这两个差集本身可测, 故测度为零, 由有限可加性得 $\mu(A) = \mu(A')$, 赋值不依赖表示。取补集时, 可把 $A \cup E$ 的补集写成 $(X \setminus (A \cup N)) \cup (N \setminus (A \cup E))$; 第二项仍是零测集的子集。取可数并时, 可测部分取并, 例外部分包含在零测集的可数并中, 因而 $\overline{\mathcal{A}}$ 是 σ 代数。对两两不交的 $A_j \cup E_j$, 其可测部分 A_j 也两两不交, μ 的可数可加性随即由 μ 继承。若 $\mu(A \cup E) = 0$, 则 $A \cup E$ 包含在原可测零测集 $A \cup N$ 中; 它的任意子集已被纳入 $\overline{\mathcal{A}}$, 所以扩展后的空间完备。

一个有限例子能看清增加了什么。取 $X = \{a, b, c\}$, $\mathcal{A} = \{\emptyset, \{a, b\}, \{c\}, X\}$, 令 $\mu(\{a, b\}) = 0$, $\mu(\{c\}) = 1$ 。原来不能单独测量 $\{a\}$; 完备化把 $\{a\}$ 、 $\{b\}$ 及其与 $\{c\}$ 的并纳入, 得到全部子集, 并把新增零测子集赋值为零。实数上的 Lebesgue 测度空间则是 Borel 长度测度空间的完备化; 新增的集合仍保持相容的长度。这里的完备性处理零测集的子集, 不同于第 3.2 节中“柯西数列不会逃出空间”的完备性。

3.2 序列的极限、累计与迭代收敛

索引族说明怎样排列对象, 尚未说明项数增加以后会发生什么。这里从熟悉的实数列出发, 再把收敛和柯西条件推广到向量及一般度量空间中的点列; 每一项不必是一个数。部分和与递推更新都产生这样的序列, 因而可以用同一套极限工具判断累计是否稳定、更新是否得到解, 以及有限步计算距离最终结果还有多远。

3.2.1 序列极限与空间完备性

3.2.1.1 数值极限与上下极限

数列 $a_n = 1/n$ 越来越接近 0, 而 $a_n = (-1)^n$ 虽然一直在 -1 与 1 之间, 却没有稳定到一个数。要区分这两种行为, 不能只看某几项是否接近目标; 必须要求从某一项开始, 后面所有项都接近它。前章已把以自然数为索引的一族数称为数列 (sequence), 记作 $(a_n)_{n \geq 1}$ 。若对每个 $\varepsilon > 0$, 都存在整数 N , 使得

$$n \geq N \implies |a_n - a| < \varepsilon,$$

就称 a_n 收敛 (converge) 到 a , 记作 $a_n \rightarrow a$ 。这一定义要求同一个 N 控制其后的全部项, 而不是只要求数列偶尔靠近 a 。极限若存在便唯一: 若 $a \neq b$ 都是极限, 取 $\varepsilon = |a - b|/3$, 充分靠后的 a_n 会同时落入两个不相交的邻域, 产生矛盾。

收敛数列必有界。事实上, 取 $\varepsilon = 1$ 后, 除有限个前项外都有 $|a_n| \leq |a| + 1$, 再把有限个前项的绝对值一并取最大值即可。反向结论通常不成立, 例如 $a_n = (-1)^n$ 有界却不收敛。若再加入单调性, 情况便不同。

这里需要使用实数的完备性 (completeness)。它的一种等价表述是确界公理：每个非空且有上界的实数集合都有实数上确界。稍后讨论柯西数列时，还会看到完备性的另一种等价表述。

定理 3.10 单调有界收敛定理 若实数列 (a_n) 单调不减且有上界，则 a_n 收敛到 $a = \sup\{a_n : n \in \mathbb{N}\}$ 。单调不增且有下界的情形类似。

证明的关键是上确界的逼近性质。对任意 $\varepsilon > 0$ ，存在某一项 $a_N > a - \varepsilon$ ；单调性保证后面所有项都不小于 a_N ，而上确界保证它们都不大于 a ，于是 $a_n \rightarrow a$ 。仅有单调性或仅有有界性都不能保证收敛： n 单调却无上界， $(-1)^n$ 有界却不单调。这一结论还依赖实数的完备性；若只在有理数中考察逐步逼近 $\sqrt{2}$ 的有理数列，所有项都在有理数中，极限却不在这个空间中。下面的柯西条件将从序列项之间的距离出发，进一步说明什么样的空间能够容纳这些极限。

无有限极限的数列称为发散，但发散不一定意味着振幅越来越大。 $(-1)^n$ 始终振荡，而 $a_n = n$ 趋于正无穷。准确地说，

$$a_n \rightarrow +\infty \iff \forall M \in \mathbb{R}, \exists N, \forall n \geq N, a_n > M;$$

趋于负无穷把最后的不等式改为 $a_n < M$ 。这不是仅要求某些项很大。 $\overline{\mathbb{R}} = \mathbb{R} \cup \{-\infty, +\infty\}$ 称为扩展实数，用于记录这类边界结果； $\infty - \infty$ 仍没有定义。

后文还会按条件使用几个熟悉结论：若 $a_n \rightarrow a$ 、 $b_n \rightarrow b$ 且 a, b 有限，和、积的极限分别是 $a + b$ 、 ab ；商的规则还要求 $b \neq 0$ 。若充分大的 n 满足 $a_n \leq c_n \leq b_n$ ，且两端同趋于 c ，夹逼定理给出 $c_n \rightarrow c$ 。这些条件防止把有界振荡误当成极限，或把有限极限的代数规则用于未定义的无穷运算。

并非每个有界数列都有极限。若尾部仍然振荡，可以先记录它最终逼近的上下边界。

定义 3.11 数列的上极限与下极限 对扩展实数列 (a_n) ，尾部下确界 $\inf_{k \geq n} a_k$ 随 n 单调不减，尾部上确界 $\sup_{k \geq n} a_k$ 随 n 单调不增。因此可在扩展实数中定义

$$\liminf_{n \rightarrow \infty} a_n = \lim_{n \rightarrow \infty} \inf_{k \geq n} a_k, \quad \limsup_{n \rightarrow \infty} a_n = \lim_{n \rightarrow \infty} \sup_{k \geq n} a_k.$$

函数列的下极限与上极限也可按每个 x 逐点定义，第 3.5 节会回用这一操作。若 a_n 收敛，则二者都等于通常极限；若不收敛，它们分别记录尾部最终能够逼近的下界与上界；不要求某一项恰好达到它们。

例如 $(-1)^n$ 的下极限为 -1 、上极限为 1 ，而通常极限不存在。总有 $\liminf a_n \leq \limsup a_n$ ；二者同为有限 a 当且仅当 $a_n \rightarrow a$ ，同为 $+\infty$ 或 $-\infty$ 时则对应上述无穷极限。上下极限相等并不自动意味着有一个有限实数极限，仍须核对共同值。

3.2.1.2 柯西序列与空间完备性

有时我们还不知道候选极限，却能证明后面的项彼此越来越近。柯西数列 (Cauchy sequence) 满足

$$\forall \varepsilon > 0, \exists N, \forall m, n \geq N, |a_m - a_n| < \varepsilon.$$

每个收敛实数列都是柯西数列，因为 $|a_m - a_n| \leq |a_m - a| + |a_n - a|$ 。反过来，每个实柯西数列也收敛；这是实数完备性的等价表述之一。柯西条件比较序列项之间的距离，不必先知道候选极限，因此适合分析尚不知道解在哪里的迭代。不过，条件仍要求所有足够靠后的项都彼此接近；只核对已经算出的有限几项，还不能证明它成立。

若能控制相邻差，还可以借助三角不等式验证柯西条件。对 $m > n$,

$$|a_m - a_n| \leq \sum_{k=n}^{m-1} |a_{k+1} - a_k|. \quad (3.2)$$

这个估计把“两个较晚的项相距多远”变成了“它们之间每一步变化累计有多大”。不过，相邻差各自趋于零还不够：中间的步数也在增加，必须控制整段和。本节随后用级数表达这种累计控制，再用压缩迭代把相邻差控制成几何衰减。

向量列的每一项是一个完整的向量。例如 $\mathbf{x}_n = (1/n, (-1)^n/n)^\top$ 满足 $\|\mathbf{x}_n - \mathbf{0}\|_2 = \sqrt{2}/n \rightarrow 0$ ，所以它在欧氏距离下趋于零向量。有限维中逐个坐标趋近与欧氏距离趋近等价；换成一般对象以后，应直接使用选定的距离。

定义 3.12 度量空间中的收敛与柯西数列 点列 (x_n) 在 (X, d) 中收敛到 x ，是指

$$\forall \varepsilon > 0, \exists N, n \geq N \implies d(x_n, x) < \varepsilon;$$

等价地， $d(x_n, x) \rightarrow 0$ 。点列 (x_n) 称为柯西数列，是指

$$\forall \varepsilon > 0, \exists N, m, n \geq N \implies d(x_m, x_n) < \varepsilon.$$

这两条定义分别把实数中的 $|a_n - a|$ 与 $|a_m - a_n|$ 替换为一般距离。

比较同一个集合 $\mathbb{R}$ 上的通常度量 $d_1(x, y) = |x - y|$ 与离散度量 $d_2(x, y) = \mathbb{I}\{x \neq y\}$ 。对 $x_n = 1/n$,

$$d_1(x_n, 0) = 1/n \longrightarrow 0, \quad d_2(x_n, 0) = 1.$$

因此它在通常度量下收敛到 0, 在离散度量下却不收敛到 0。在离散度量中, 取 $\varepsilon = 1/2$ 就会要求充分靠后的项恰好等于极限; 只是在数值上越来越小并不够。图 3.2 左侧把这两种判断并排画出, 右侧则在第 3.3.1 节讨论连续性时回用。

有理数可以不断逼近 $\sqrt{2}$, 却无法在有理数空间中取到这个极限。因此, 即使证明迭代满足柯西条件, 还需要确认它在所考察的空间内有极限。

定义 3.13 完备度量空间 度量空间 (X, d) 若每个柯西数列都收敛到 X 中的点, 就称为完备 (complete)。

实数空间与有限维欧氏空间完备, 有理数空间在通常距离下不完备。完备性保证每个柯西序列在空间内都有极限。任意序列仍可能不收敛, 例如实数空间中的 $(-1)^n$; 这种序列没有满足柯西条件。

例如取有理数 $a_n = 10^{-n} \lfloor 10^n \sqrt{2} \rfloor$, 则 $0 \leq \sqrt{2} - a_n < 10^{-n}$, 所以它在 $\mathbb{R}$ 中收敛, 也在 $\mathbb{Q}$ 中满足柯西条件; 若在 $\mathbb{Q}$ 中有极限, 极限唯一性又迫使该极限为不属于 $\mathbb{Q}$ 的 $\sqrt{2}$ 。这列数彼此确实越来越接近, 但它所接近的点不属于有理数空间。

引理 3.14 闭集的序列判据 设 C 为度量空间 X 的子集。 C 闭当且仅当: 对每个由 C 中点组成的序列, 若 $x_n \rightarrow x$ 在 X 中成立, 则 $x \in C$ 。

证明. 若 C 闭而 $x \notin C$, 开集 $X \setminus C$ 包含某个 $B(x, r)$ 。收敛要求充分靠后的 x_n 落入这个球, 与 $x_n \in C$ 矛盾。反之, 若 C 不闭, 则存在 $x \in X \setminus C$, 使每个 $B(x, r)$ 都与 C 相交。为每个 n 选 $x_n \in C \cap B(x, 1/n)$, 便有 $x_n \rightarrow x \notin C$, 违反序列条件。 ■

因此, 完备度量空间的闭子集在继承的距离下也完备: 子集中的柯西列先在母空间收敛, 闭性再保证极限仍在子集中。反过来, 任一完备子空间在母度量空间中都是闭的, 因为在母空间收敛的子空间点列必为柯西列, 子空间内的极限由唯一性等于原极限。闭与有界描述不同性质; 例如 $(0, 1)$ 有界但不闭, $\mathbb{R}$ 闭但不有限。两种完备性也不可互代: 前面的三点空间配上离散距离后, 柯西列最终常值, 所以度量空间完备, 原测度空间却未完备; $(0, 1)$ 的 Lebesgue 测度已完备, 通常距离却不完备。

3.2.2 级数收敛与累计误差

3.2.2.1 部分和与级数收敛

数列 (a_n) 记录一组按索引排列的数；级数研究的是把这些数依次相加后的累计结果。第 1 章的有限和只加到指定的 N ，得到

$$s_N = \sum_{n=1}^N a_n = a_1 + a_2 + \cdots + a_N.$$

s_N 称为部分和 (partial sum)。让 N 不断增加，又得到一个新的数列 (s_N) ：原数列的每一项是 a_n ，新数列的每一项是前 N 项的总和。符号 无穷级数 (infinite series) $\sum_{n=1}^{\infty} a_n$ 描述的正是这一求和过程；只有当部分和数列有有限极限 s 时，才称级数收敛，并把这个极限记作 $\sum_{n=1}^{\infty} a_n = s$ 。

例如， $a_n = 2^{-n}$ 作为数列趋于 0，对应的部分和却是 $s_N = 1 - 2^{-N}$ ，趋于 1。这两个极限回答不同的问题：单个新增项是否变小，以及全部新增项的累计量是否稳定。取 $s_0 = 0$ ，级数收敛必然推出 $a_n = s_n - s_{n-1} \rightarrow 0$ ，但单项趋零并不足够。例如调和级数 $\sum_{n=1}^{\infty} 1/n$ 发散。把从 2^k 到 $2^{k+1} - 1$ 的项分成一组，该组有 2^k 项，每项至少为 $1/2^{k+1}$ ，所以每组之和至少为 $1/2$ ；部分和因而可以超过任意给定常数。

当 $|r| < 1$ 时，有限几何和

$$\sum_{n=0}^N r^n = \frac{1 - r^{N+1}}{1 - r}$$

在 $N \rightarrow \infty$ 时给出

$$\sum_{n=0}^{\infty} r^n = \frac{1}{1 - r}. \quad (3.3)$$

$|r| < 1$ 不可删去： $r = 1$ 时部分和不断增长， $r = -1$ 时部分和振荡， $|r| > 1$ 时单项甚至不趋于零。折扣回报和几何误差界都依赖这一条件。

3.2.2.2 绝对收敛与尾和控制

计算只能取有限项，因此还要知道遗漏的尾部有多大。若级数收敛到 s ，记 $R_N = s - s_N$ ；能用非负尾和控制 $|R_N|$ 时，就不必依赖正负误差的偶然相消。若 $\sum_n |a_n| < \infty$ ，就称级数绝对收敛 (absolutely converge)。由式 (3.2) 对应的尾和估计，绝对收敛蕴含收敛。回到柯西条件，若 $\sum_k |a_{k+1} - a_k|$ 收敛，其尾和就能统一控制任意 $m > n$ 的差，从而保证 (a_n) 是柯西数列。绝对收敛还允许重新排列求和次序而保持级数的和；只有条件收敛时，重排可能改变和甚至使其发散。定理 3.41 中的 Fubini 结论，是这一原则在积分上的对应版本。

具体地, $|R_N| \leq \sum_{n>N} |a_n| \rightarrow 0$ 。任意重排只要已经包含原来前 N 项, 其尚未计算的贡献就都来自这个绝对尾和, 故不会改变最终的和。收敛但不绝对收敛称为条件收敛, 例如 $\sum_{n \geq 1} (-1)^{n+1}/n$; 正项总和与负项绝对值总和都发散, 改动二者进入部分和的次序便可能改变相消结果。这个例子也说明, 有限和的交换律不能不加条件地搬到无穷和。

下面的步长例子用到 p 级数 $\sum_{n \geq 1} n^{-p}$: 它恰在 $p > 1$ 时收敛。不借助积分也能核对这一条件。对 $p > 0$, 第 k 组 $n = 2^k, \dots, 2^{k+1} - 1$ 的和介于 $2^{-p}2^{k(1-p)}$ 与 $2^{k(1-p)}$ 之间; $p > 1$ 时可用几何级数控制, $0 < p \leq 1$ 时各组之和不趋于零。 $p \leq 0$ 时原级数的单项已不趋于零。

设第 t 步计算产生非负误差 δ_t 。“单步误差趋零”只表示 $\delta_t \rightarrow 0$; “前 T 步累计误差”是 $\sum_{t=0}^{T-1} \delta_t$; “误差可求和”则要求 $\sum_{t=0}^{\infty} \delta_t < \infty$ 。三者不能混用。例如 $\delta_t = 1/(t+1)$ 逐步趋零, 但累计误差无界; $\delta_t = 1/(t+1)^2$ 才可求和。若误差进入第1章式(1.6)那样的稳定递推, 较早误差还会被几何权重衰减, 此时应分析加权累计量, 而不是只看 δ_t 本身。

在迭代更新 $x^{(t+1)} = x^{(t)} + \alpha_t v_t$ 中, v_t 给出本轮更新方向, $\alpha_t \geq 0$ 控制更新幅度, 称为步长。若更新量 v_t 有界而步长总和有限, 则全部更新的位移也可由一个有限的和控制, 算法可能还未到达目标就失去了足够的移动幅度。某些带噪声的迭代分析又用步长的平方和估计噪声累计影响, 希望这个和有限。因此, 同一个步长序列可能需要满足“步长总和无限”和“步长平方和有限”这两种不同要求。典型条件

$$\sum_{t=1}^{\infty} \alpha_t = \infty, \quad \sum_{t=1}^{\infty} \alpha_t^2 < \infty$$

可由 $\alpha_t = 1/t$ 满足: 第一项是调和级数, 第二项是收敛的 p 级数。这里尚不能据此推出随机算法收敛, 因为还缺少噪声和目标函数的条件; 这个例子只说明两个累计对象可以有不同结论。后续分析折扣、步长和扰动时, 都应先问清趋零的是哪一项、累计采用什么权重, 以及所需级数是否真的收敛。

第2.1.1.1节用大 O 和小 o 比较规模; 这里的收敛使小 o 中的比值趋零有了明确含义。若 $b_n > 0$ 最终成立, $a_n = o(b_n)$ 要求 $a_n/b_n \rightarrow 0$, 不仅要求比值有界。例如 $1/n = O(1/n)$, 却不是 $o(1/n)$; $1/n^2 = o(1/n)$ 。比较误差时必须固定趋向和分母尺度, 不能由单项趋零推出累计可求和。

3.2.3 迭代收敛与误差控制

3.2.3.1 压缩迭代与停止误差

第1章的递推给出每一步怎样计算; 现在还要保证这些点列的极限确实是更新方程的解。证明这件事需要两步: 用统一压缩把相邻变化控制成几何

尾和，从而验证柯西条件；再用空间完备性保证极限存在。还要检查这个极限满足原更新方程，才能把它称为解。

寻找更新方程的解，就是寻找更新前后不再变化的点。

定义 3.15 不动点 设 $T : X \rightarrow X$ 为映射。点 $x^* \in X$ 若满足 $T(x^*) = x^*$ ，就称为 T 的不动点 (fixed point)。

如果每次更新都把任意两点的距离缩小到原来的同一个比例以下，就能把相邻迭代的距离控制成几何衰减。把这一要求施加到更新映射上，得到下面的条件。

定义 3.16 压缩映射 设 (X, d) 为度量空间。映射 $T : X \rightarrow X$ 若存在 $q \in [0, 1)$ 使

$$d(Tx, Ty) \leq qd(x, y) \quad \text{对所有 } x, y \in X, \quad (3.4)$$

就称为压缩映射 (contraction mapping)。

关键是同一个 $q < 1$ 在整个所考察空间上成立，并且 T 确实把 X 映回自身²。

² J. B. Conway, *A Course in Functional Analysis*, Springer, 1990, 2nd ed.

定理 3.17 Banach 压缩映射定理 设 (X, d) 是非空完备度量空间， $T : X \rightarrow X$ 为压缩映射，压缩因子为 $q < 1$ 。则 T 有唯一不动点 $x^* \in X$ 。从任意 $x^{(0)} \in X$ 出发定义 $x^{(n+1)} = T(x^{(n)})$ ，都有 $x^{(n)} \rightarrow x^*$ ，并且

$$d(x^{(n)}, x^*) \leq \frac{q^n}{1-q} d(x^{(1)}, x^{(0)}), \quad (3.5)$$

$$d(x^{(n)}, x^*) \leq \frac{q}{1-q} d(x^{(n)}, x^{(n-1)}) \quad (n \geq 1). \quad (3.6)$$

证明. 反复使用压缩条件可得

$$d(x^{(n+1)}, x^{(n)}) \leq q^n d(x^{(1)}, x^{(0)}).$$

对 $m > n$, 三角不等式和几何级数给出

$$\begin{aligned} d(x^{(m)}, x^{(n)}) &\leq \sum_{k=n}^{m-1} d(x^{(k+1)}, x^{(k)}) \\ &\leq d(x^{(1)}, x^{(0)}) \sum_{k=n}^{m-1} q^k \\ &\leq \frac{q^n}{1-q} d(x^{(1)}, x^{(0)}). \end{aligned}$$

右边随 $n \rightarrow \infty$ 趋于零, 所以 $(x^{(n)})$ 是柯西数列。完备性保证存在 $x^* \in X$ 使 $x^{(n)} \rightarrow x^*$ 。由压缩条件与三角不等式,

$$\begin{aligned} d(Tx^*, x^*) &\leq d(Tx^*, Tx^{(n)}) + d(x^{(n+1)}, x^*) \\ &\leq qd(x^*, x^{(n)}) + d(x^{(n+1)}, x^*) \longrightarrow 0. \end{aligned}$$

左侧不依赖 n , 故 $T(x^*) = x^*$ 。

若 y^* 也是不动点, 则

$$d(x^*, y^*) = d(Tx^*, Ty^*) \leq qd(x^*, y^*).$$

因为 $q < 1$, 只能有 $d(x^*, y^*) = 0$, 故不动点唯一。

在上面的柯西界中令 $m \rightarrow \infty$, 便得式 (3.5)。若从第 $n-1$ 步重新计算同一界,

$$d(x^{(n)}, x^*) \leq \sum_{k=n}^{\infty} d(x^{(k+1)}, x^{(k)}) \leq d(x^{(n)}, x^{(n-1)}) \sum_{j=1}^{\infty} q^j,$$

便得到式 (3.6)。 ■

这个证明同时说明存在、唯一和可计算的误差界各来自哪里: 几何尾和使迭代为柯西列, 完备性把极限留在空间中, 压缩距离估计使极限成为不动点, 严格的 $q < 1$ 保证唯一性。若只允许 $q = 1$, 结论都可能丢失。恒等映射 $T(x) = x$ 有无穷多个不动点; $T(x) = x + 1$ 在 $\mathbb{R}$ 上没有不动点, 且相应迭代发散。满足 $q = 1$ 的距离上界时, 映射只保证不放大距离, 称为非扩张; 它缺少 $q < 1$ 带来的严格缩小。完备性也不能省略。在非完备空间 $X = (0, 1)$ 上, 映射 $T(x) = x/2$ 是压缩因子为 $1/2$ 的自映射, 但它唯一的不动点是被排除的 0 。从任意 $x^{(0)} \in X$ 出发, 迭代 $x^{(n)} = x^{(0)}/2^n$ 在 $\mathbb{R}$ 中趋于 0 , 却不在 X 中收敛。

先验界在计算前给出所需步数, 后验界则使用已经算出的相邻两步距离。例如在 $\mathbb{R}$ 上取 $T(x) = x/2 + 1$, $x^{(0)} = 0$, 则 $q = 1/2$, $x^{(1)} = 1$, 唯一不动点为 2 。先验界给出 $|x^{(n)} - 2| \leq 2^{1-n}$; 要求误差不超过 10^{-3} 时, $n = 11$ 已足够。后验界在这里化为 $|x^{(n)} - 2| \leq |x^{(n)} - x^{(n-1)}|$, 因此, 只要相邻两

步的差不超过所需精度，就能据此停止，而无需事先知道答案 2。一般 q 接近 1 时，因子 $q/(1-q)$ 可能很大，“相邻两步已经很近”不能独自作为到解误差很小的证据。 $q=0$ 时映射为常值，一步即到不动点。

3.2.3.2 扰动迭代与累计误差

精确更新的压缩性不代表数值实现没有误差。设 T 满足压缩条件，精确轨迹为 $x^{(t+1)} = T(x^{(t)})$ ，计算轨迹为 $z^{(t)}$ ，且每次更新满足 $d(z^{(t+1)}, T(z^{(t)})) \leq \delta_t$ ，其中 $\delta_t \geq 0$ 。令 $e^{(t)} = d(z^{(t)}, x^{(t)})$ ，三角不等式给出

$$\begin{aligned} e^{(t+1)} &\leq d(z^{(t+1)}, T(z^{(t)})) + d(T(z^{(t)}), T(x^{(t)})) \\ &\leq \delta_t + \rho e^{(t)}, \quad 0 \leq \rho < 1. \end{aligned} \quad (3.7)$$

这里 ρ 就是所用压缩因子。对到不动点的误差 $d(z^{(t)}, x^*)$ 也有同一递推。把不等式逐次代入，或对 t 归纳，得到

$$e^{(t)} \leq \rho^t e^{(0)} + \sum_{s=0}^{t-1} \rho^{t-1-s} \delta_s. \quad (3.8)$$

这正是第 1 章式 (1.7) 的有限展开在距离误差中的应用；本章再判断它随 t 增加的行为。若 $\delta_s \leq \bar{\delta}$ ，则 $e^{(t)} \leq \rho^t e^{(0)} + \bar{\delta}(1 - \rho^t)/(1 - \rho)$ ，所以 $\limsup_t e^{(t)} \leq \bar{\delta}/(1 - \rho)$ 。这是最坏误差范围，不是断言每条计算轨迹都收敛到这个上界。

示例 3.18 持续扰动与衰减扰动 取 $e^{(0)} = 1$ 、 $\rho = 1/2$ ，并暂把递推中的不等号取为等号。若每步都加入 $\delta_t = 0.1$ ，展开式给出

$$e^{(t)} = 2^{-t} + 0.1 \sum_{s=0}^{t-1} 2^{-s} = 0.2 + 0.8 \cdot 2^{-t}.$$

初始误差逐步消失，持续加入的误差却留下 0.2 的极限。若改为 $\delta_t = 0.1/(t+1)$ ，扰动本身也衰减，稳定递推便使 $e^{(t)} \rightarrow 0$ 。例如第 1 步两者都是 0.6，第 2 步分别为 0.4 和 0.35；差别来自第二步加入的新误差，而不是初值不同。这里的 $1/(t+1)$ 扰动并不可求和，几何权重仍能使其累计影响趋于零；可求和性是更强的条件。

衰减扰动的结论可以直接由有限展开式 (3.8) 核对。给定 $\varepsilon > 0$ ，先选 S 使 $s \geq S$ 时 $\delta_s \leq \varepsilon(1 - \rho)/2$ 。对 $t > S$ 把累计和拆成两段：前 S 项是有限个旧扰动，其权重随 t 几何趋零；后面的项满足

$$\sum_{s=S}^{t-1} \rho^{t-1-s} \delta_s \leq \frac{\varepsilon(1 - \rho)}{2} \sum_{j=0}^{t-1-S} \rho^j \leq \frac{\varepsilon}{2}.$$




图 3.1 相同初值与收缩系数下的两种递推。蓝线使用持续扰动，红线使用衰减扰动；每个点都是整数步上的精确递推值，图中 $e(t)$ 对应正文的 $e^{(t)}$ ，灰虚线是持续扰动留下的极限 0.2。图为教学构造。

旧扰动项和初始误差在充分大的 t 后也不超过 $\varepsilon/2$ ，因此总误差趋于零。这里需要 $0 \leq \rho < 1$ 、 $\delta_s \rightarrow 0$ 和有限的初始误差；只写“每步误差很小”仍不足够。

3.3 函数的连续性与局部变化

输入越来越接近一个点时，函数输出是否也接近该点的输出？若输入只移动很小一段，能否估计输出变化的方向和大小？本节固定一个函数，先用连续性回答前一个问题，再用导数与 Taylor 近似回答后一个问题。若函数只由方程间接规定，还要先保证方程确实确定一个局部函数；遇到尖点或跳跃，则要重新检查什么变化信息仍可使用。

3.3.1 连续性与扰动控制

确定输入与输出的距离后，可以要求小的输入扰动只引起小的输出扰动。这就把熟悉的实函数连续性推广到一般度量空间。

定义 3.19 度量空间中的连续映射 设 (X, d_X) 与 (Y, d_Y) 为度量空间。函数 $f: X \rightarrow Y$ 在 $x \in X$ 处连续 (continuous), 是指

$$\forall \varepsilon > 0, \exists \delta > 0, \forall x' \in X, \\ d_X(x, x') < \delta \implies d_Y(f(x), f(x')) < \varepsilon.$$

若 f 在每个 $x \in X$ 处连续, 则称 f 在 X 上连续。

这里 δ 可以依赖 x 和 ε 。等价地, 只要 $x_n \rightarrow x$, 就有 $f(x_n) \rightarrow f(x)$ 。连续函数因而允许把一个已经存在的极限送入函数: $f(\lim_n x_n) = \lim_n f(x_n)$ 。这里必须同时说明输入和输出采用的度量。

例如恒等映射 $F(x) = x$ 从 $(\mathbb{R}, d_1)$ 映到 $(\mathbb{R}, d_2)$ 时处处不连续。在任意 x 附近, 总能找到通常距离任意小但不等于 x 的 x' , 它们的输出距离却始终为 1, 无法小于 $\varepsilon = 1/2$ 。反过来, 从 $(\mathbb{R}, d_2)$ 到 $(\mathbb{R}, d_1)$ 的同一公式连续: 选 $\delta = 1/2$, 输入距离小于 δ 就只可能有 $x' = x$, 输出距离于是为 0。这不是函数公式发生变化, 而是输入输出空间对“附近”的判断不同。图 3.2 右侧显示前一种失败。




图 3.2 数值相同, 距离不同。图中 d_u, d_d 分别对应正文的通常距离 d_1 与离散距离 d_2 。(a) 数列 $x_n = 1/n$ 到 0 的通常距离趋于零, 离散距离却恒为 1, 所以收敛要连同度量说明。(b) 恒等映射从通常度量空间映入离散度量空间时, 任意非零且很小的输入位移仍对应输出距离 1, 不能进入 $\varepsilon = 1/2$ 的输出邻域, 故它在 0 处不连续。图为解析教学示例。

普通连续性允许在每个位置选取不同大小的输入邻域。若要在整个定义域中使用同一个输入精度, 就需要把这些逐点要求统一起来。

定义 3.20 一致连续映射 设 (X, d_X) 与 (Y, d_Y) 为度量空间, $f : X \rightarrow Y$ 。若对每个 $\varepsilon > 0$ 都能找到一个与具体位置无关的 $\delta > 0$, 使任意 $x, x' \in X$ 只要 $d_X(x, x') < \delta$ 便有 $d_Y(f(x), f(x')) < \varepsilon$, 就称 f 一致连续 (uniformly continuous)。

连续性允许不同位置使用不同的 δ , 一致连续则要求同一个 δ 同时控制整个定义域。连续性本身并不足以给出这种统一控制: $f(x) = x^2$ 在 $\mathbb{R}$ 上连续, 令 $x \rightarrow +\infty$ 并取 $x' = x + 1/x$, 可见输入距离趋于零而输出距离 $|f(x') - f(x)| = 2 + 1/x^2$ 不趋于零。

统一控制还可以更具体: 若输入误差为 r , 能否保证输出误差不超过某个常数乘以 r ? 这样的线性误差界正是 Lipschitz 条件。

定义 3.21 Lipschitz 连续映射 设 (X, d_X) 与 (Y, d_Y) 为度量空间, $f : X \rightarrow Y$ 。若存在有限常数 $L \geq 0$, 使所有 $x, x' \in X$ 都满足

$$d_Y(f(x), f(x')) \leq L d_X(x, x'), \quad (3.9)$$

则称 f 为 L -Lipschitz 连续 (Lipschitz continuous)。

它不仅用同一个 δ 控制整个定义域, 还给出输出变化相对于输入变化的线性上界, 因而蕴含一致连续。函数 $f(x) = \sqrt{x}$ 在 $[0, 1]$ 上满足 $|\sqrt{x} - \sqrt{x'}| \leq \sqrt{|x - x'|}$, 因而选 $\delta = \varepsilon^2$ 就得到一致连续性, 却不能得到 Lipschitz 连续性: 若存在有限 L , 令 $x' = 0$ 便会要求 $\sqrt{x} \leq Lx$, 即 $1/\sqrt{x} \leq L$, 这在 $x \downarrow 0$ 时不可能成立。同一个公式在不同定义域上可能具有不同的统一控制。 $f(x) = x^2$ 在 $[0, 1]$ 上满足 $|x^2 - z^2| \leq 2|x - z|$, 因而 2-Lipschitz; 在整个实线上却没有有限的全局 Lipschitz 常数。这两个例子说明, 统一的 ε - δ 控制与线性误差上界仍是不同要求。

局部 Lipschitz 函数 (locally Lipschitz function) 要求每个点附近的函数变化都能由某个有限 Lipschitz 常数控制。与全局 Lipschitz 条件不同, 各个邻域可以使用不同的常数。

定义 3.22 局部 Lipschitz 函数 设 $U \subseteq \mathbb{R}^d$ 为开集, $f : U \rightarrow \mathbb{R}$ 。若对每个 $x \in U$, 都存在半径 $r > 0$ 与有限常数 $L \geq 0$, 使 $B(x, r) \subseteq U$, 并且

$$|f(y) - f(z)| \leq L \|y - z\|_2 \quad \text{对所有 } y, z \in B(x, r) \text{ 成立,}$$

则称 f 在 U 上局部 Lipschitz。

这里 r 与 L 可以依赖中心点；一旦邻域确定，同一个 L 须控制其中的任意两点。例如 $f(x) = x^2$ 在任意 $(x_0 - r, x_0 + r)$ 上可取 $L = 2(|x_0| + r)$ ，所以在实轴上局部 Lipschitz，却不是全局 Lipschitz。向量值函数也用输出范数替换绝对值，作完全相同的局部定义。局部控制要提升为区域内的统一控制，还需要区域或导数的额外条件。

第1章已区分下确界与最小值：数值可以逼近一个下界，却始终找不到达到它的点。要从近似最优点列中找到一个仍属于可行范围的极限点，需要防止点列逃向无穷远或被排除的边界。在一般度量空间中，承担这一职责的是紧致性。

定义 3.23 开覆盖与紧致性 设 (X, d) 为度量空间， $K \subseteq X$ 。若一族 X 中的开集的并包含 K ，就称这族开集为 K 的 **开覆盖** (open cover)；若从中选出的有限个开集仍覆盖 K ，它们就构成 **有限子覆盖** (finite subcover)。集合 K 的每个开覆盖都能选出有限子覆盖时，称 K 为 **紧致** (compact)。

在度量空间中，这一定义等价于 **序列紧致性**：集合中的每个序列都有一个子序列收敛到仍在该集中的点。后一种表述更适合分析算法产生的点列，因为它直接提供候选极限。

紧致性还能把逐点连续提升为一致连续：连续映射在紧致定义域上一定一致连续。这为前面闭区间上的统一控制提供了一个一般条件，但不保证 Lipschitz 连续； $\sqrt{x}$ 的例子已说明，输出变化未必能由输入距离的一次常数倍控制。

在有限维欧氏空间 $\mathbb{R}^d$ 中，Heine–Borel 定理说明紧致等价于闭且有界。这个结论不能原样搬到一般度量空间。考虑所有有界实数序列组成的空间

$$\ell^\infty = \left\{ \mathbf{x} = (x_1, x_2, \dots) : \sup_{k \geq 1} |x_k| < \infty \right\}, \quad d(\mathbf{x}, \mathbf{y}) = \sup_{k \geq 1} |x_k - y_k|.$$

令 $\mathbf{e}_n$ 只有第 n 个坐标为 1，其余坐标为 0。集合 $\{\mathbf{e}_n : n \geq 1\}$ 有界。两个不同元素之间的距离为 1，因此由这些点组成的收敛序列只能最终固定在某一个点上，极限仍属于该集合；闭集的序列判据说明它也是闭集。但按 $n = 1, 2, \dots$ 依次取出的 $\mathbf{e}_n$ 中，任何子序列的不同项都相距 1，所以都不是柯西数列，更不可能收敛。一般空间中“闭且有界”不足以替代紧致，正是因为无穷多个彼此分离的方向可能留在同一个有界球内。

定理 3.24 紧致集上的极值定理 设 K 是非空紧致度量空间， $f : K \rightarrow \mathbb{R}$ 连续，则 f 在 K 上同时达到最小值与最大值。

可以从近似最优值看清这些条件的作用。连续函数在紧致集合上先是有界的：否则可以选出函数值绝对值不断增大的点列，紧致性给出一个收敛子序列，连续性却要求相应函数值收敛到有限值，产生矛盾。有了有限下确界，再选一系列函数值趋近下确界的点。紧致性保证其中有子序列收敛到集合内的点，连续性保证该点的函数值恰等于下确界，因而取得最小值。对 $-f$ 应用同一论证便得到最大值。下面的例子说明，去掉紧致性或连续性后，极值可能不存在。

示例 3.25 极值存在条件怎样失效 在开区间 $(0,1)$ 上，连续函数 $f(x) = x$ 的下确界为 0，却没有最小点；定义域不紧致，极限点 0 被排除。把定义域改成闭但不紧致的 $\mathbb{R}$ ，连续函数 $f(x) = e^x$ 仍有下确界 0 而不达到它。另一方面，在紧致集合 $[0,1]$ 上定义

$$g(0) = 1, \quad g(x) = x \quad (x > 0),$$

则 $\inf g = 0$ 也未达到；这次失败的是 g 在 0 处不连续。三个例子分别表明“连续”、“闭”或“有界”中的单独一项都不是一般的极值存在保证。

连续性与可导性也应分开。回顾一元情形，导数要求左右两侧的差商趋向同一斜率，比函数值趋近本身更强： x^2 光滑， $|x|$ 在 0 连续但有尖点，阈值函数 $\mathbb{I}_{x \geq 0}$ 则在 0 跳跃。尖点只阻止共同斜率，跳跃连共同的函数值极限也破坏了。图 3.3 把三者放在同一位置比较；下一小节将写出差商和整体线性近似的正式条件。




图 3.3 三个不同的局部性质。(a) $f(x) = x^2$ 在 0 处可用 $\delta = 1/2$ 控制 $\epsilon = 1/4$ ：严格位于输入邻域内的点，其函数值严格落在输出邻域内。(b) 阶跃函数在 0 的左极限为 0，取值却为 1，空心点和实心点区分两者。(c) $|x|$ 在 0 处连续，但左右导数分别为 -1 和 1 ，不存在共同的双侧导数。图中曲线均为解析教学示例。

3.3.2 一阶导数与线性近似

连续性只保证小扰动不会引起固定幅度的跳变；若还要预测变化的方向和大小，就要寻找一个作用于扰动的线性映射。本节先建立这个近似，再处理不同输入输出形状：向量输出需要 Jacobian 矩阵，复合映射需要串联两层线性变化，矩阵变量则需要用迹内积表示同一个一阶变化。这里的“一阶”指对输入扰动保留线性项，与下一节研究斜率变化的二阶导数相对。

3.3.2.1 导数与全微分

从一元函数开始，把输出增量除以输入增量，得到这一小段上的平均变化率；输入增量趋零后若仍有稳定值，就用它预测附近的输出。

一元函数 $f: \mathbb{R} \rightarrow \mathbb{R}$ 在 x 处的导数 (derivative) 定义为

$$f'(x) = \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h},$$

前提是这个双侧极限存在。它说明输入发生小变化 h 时，函数增量的一阶部分是 $f'(x)h$ ：

$$f(x+h) = f(x) + f'(x)h + o(|h|). \quad (3.10)$$

第 2.1.1.1 节的小 o 仍表示相对余项趋零，不过这里的趋向是 $h \rightarrow 0$ ：余项 $r(h)$ 满足 $r(h)/|h| \rightarrow 0$ ，不只是 h 本身很小。导数存在必然推出函数在该点连续，但连续不保证可导，例如 $|x|$ 在 0 处连续，左右导数却分别为 -1 和 1 。这也解释了图中尖点与跳跃的区别；两者都不能使用经典双侧导数，失效的层次却不同。

对 $f: \mathbb{R}^d \rightarrow \mathbb{R}$ ，沿方向 $\mathbf{v} \in \mathbb{R}^d$ 的方向导数 (directional derivative) 是

$$D_{\mathbf{v}}f(\mathbf{x}) = \lim_{t \rightarrow 0} \frac{f(\mathbf{x} + t\mathbf{v}) - f(\mathbf{x})}{t}.$$

取 $\mathbf{v}$ 为第 j 个坐标方向 $\mathbf{e}_j$ ，就得到偏导数 (partial derivative) $\partial f / \partial x_j$ 。方向导数只检查一条直线，而整体可微性要求所有小扰动共享同一个线性近似。

函数 $f: \mathbb{R}^d \rightarrow \mathbb{R}$ 在 $\mathbf{x}$ 处可微 (differentiable)，是指存在一个线性映射 $A: \mathbb{R}^d \rightarrow \mathbb{R}$ ，使

$$f(\mathbf{x} + \mathbf{h}) = f(\mathbf{x}) + A(\mathbf{h}) + o(\|\mathbf{h}\|_2). \quad (3.11)$$

线性部分 $A(\mathbf{h})$ 称为全微分，也记为 $df_{\mathbf{x}}(\mathbf{h})$ 。条件要求对任意趋零的非零扰动 $\mathbf{h}$ 都有 $|f(\mathbf{x} + \mathbf{h}) - f(\mathbf{x}) - A(\mathbf{h})| / \|\mathbf{h}\|_2 \rightarrow 0$ ，而不是先固定一个方向，

再允许误差控制随方向改变。在欧氏空间中，每个这样的线性泛函都可写为 $A(\mathbf{h}) = \langle \nabla f(\mathbf{x}), \mathbf{h} \rangle$ ，其中

$$\nabla f(\mathbf{x}) = \left(\frac{\partial f}{\partial x_1}(\mathbf{x}), \dots, \frac{\partial f}{\partial x_d}(\mathbf{x}) \right)^\top$$

称为**梯度** (gradient)。梯度把全微分的线性系数收集为一个向量；它与扰动 $\mathbf{h}$ 的内积，就是函数的一阶变化。

可微必然推出所有方向导数存在，并且 $D_{\mathbf{v}}f(\mathbf{x}) = \langle \nabla f(\mathbf{x}), \mathbf{v} \rangle$ 。反向结论不成立。下面先检查较弱的“各个偏导数都存在”，再检查“全部双侧方向导数都存在”；两种条件都未必能给出同一个线性近似。

示例 3.26 偏导数存在但不可微 定义 $f: \mathbb{R}^2 \rightarrow \mathbb{R}$ 为

$$f(x, y) = \begin{cases} \frac{xy}{\sqrt{x^2 + y^2}}, & (x, y) \neq (0, 0), \\ 0, & (x, y) = (0, 0). \end{cases}$$

沿两条坐标轴，函数恒为 0，所以 $\partial f / \partial x(0, 0) = \partial f / \partial y(0, 0) = 0$ 。若 f 在原点可微，候选线性部分只能是零映射。可是沿 $\mathbf{h} = (t, t)$,

$$\frac{|f(t, t) - f(0, 0)|}{\|(t, t)\|_2} = \frac{|t|/\sqrt{2}}{\sqrt{2}|t|} = \frac{1}{2},$$

余项与 $\|\mathbf{h}\|_2$ 之比不趋于零，故 f 在原点不可微。偏导数只看坐标轴，遗漏了其他接近路径。本例沿每个方向 $\mathbf{v} = (a, b)$ 的正向方向导数都存在，这里只令 $t \downarrow 0$ ，得到 $ab/\sqrt{a^2 + b^2}$ (零方向取 0)；它却不是关于 $\mathbf{v}$ 的线性函数，而且双侧方向导数在 $ab \neq 0$ 时不存在。方向极限采用单侧还是双侧，必须与所用定义一致；本节定义采用双侧极限。

即使每个双侧方向导数都存在，也未必可微。例如令 $g(x, y) = x^3/(x^2 + y^2)$ 于非零点， $g(0, 0) = 0$ 。沿 $\mathbf{v} = (a, b) \neq \mathbf{0}$ 有 $D_{\mathbf{v}}g(0, 0) = a^3/(a^2 + b^2)$ ，但坐标方向导数给出的候选梯度为 $(1, 0)^\top$ ，它对方向 $(1, 1)^\top$ 预测 1 而非实际的 1/2。这些方向变化率无法拼成一个线性映射。与前例的单侧方向极限相比，这里直接检验了本节采用的双侧定义。

要保证这些局部变化率能够形成一个全微分，常用的充分条件是： f 的所有一阶偏导数在 $\mathbf{x}$ 的某个邻域内存在，并在 $\mathbf{x}$ 处连续。此时 f 在 $\mathbf{x}$ 处可微。这个条件便于核对，但只是充分条件；可微函数的偏导数未必在该点附近连续。

用 $f(x) = x^3 - 3x$ 保留一个贯穿例子。在 $x_0 = 1/2$ 处，

$$f(x_0) = -\frac{11}{8}, \quad f'(x_0) = 3x_0^2 - 3 = -\frac{9}{4}.$$

输入改变 h 时, 一阶近似给出

$$T_1(h) = f(x_0) + f'(x_0)h = -\frac{11}{8} - \frac{9}{4}h. \quad (3.12)$$

取 $h = 0.1$, $T_1(h) = -1.600$, 而实际 $f(0.6) = -1.584$ 。近似抓住了下降方向和主要变化量, 但还有 0.016 的误差; 第 3.3.3 节将用曲率解释这部分差别。

3.3.2.2 复合映射与链式法则

当一个输入产生多个输出时, 每个输出都有一行局部线性系数, 把这些行排在一起便得到 Jacobian 矩阵。复合计算只需再把前一层的输出扰动作为后一层的输入扰动。设 $f: \mathbb{R}^d \rightarrow \mathbb{R}^m$ 。若存在矩阵 $J_f(\mathbf{x}) \in \mathbb{R}^{m \times d}$ 使

$$f(\mathbf{x} + \mathbf{h}) = f(\mathbf{x}) + J_f(\mathbf{x})\mathbf{h} + o(\|\mathbf{h}\|_2), \quad (3.13)$$

则称 f 在 $\mathbf{x}$ 处可微, $J_f(\mathbf{x})$ 称为 Jacobian 矩阵 (Jacobian matrix)。其第 i, j 个元素是 $\partial f_i / \partial x_j$ 。矩阵有 m 行、 d 列, 因为它把 d 维输入扰动映射成 m 维输出扰动。

若 f 在 $\mathbf{x}$ 处可微, 且 $g: \mathbb{R}^m \rightarrow \mathbb{R}^p$ 在 $f(\mathbf{x})$ 处可微, 则复合映射满足

$$J_{g \circ f}(\mathbf{x}) = J_g(f(\mathbf{x}))J_f(\mathbf{x}). \quad (3.14)$$

这就是链式法则(chain rule)。维度同时给出乘法次序: $(p \times m)(m \times d) = p \times d$, 反向相乘往往没有定义。即使两个方阵能够交换书写顺序, 矩阵乘法通常也不交换, 不能据标量求导经验调换因子。

上面的 g 允许向量输出。当 $p = 1$ 时, g 把中间向量变成一个标量。在优化问题中, 这个标量通常是待最小化的目标值, 本书便把此时的 g 记为 ℓ 。令 $\mathbf{y} = f(\mathbf{x})$, 总目标就是 $L(\mathbf{x}) = \ell(f(\mathbf{x}))$; ℓ 只是原复合映射的最后一层, 并没有增加一个未说明的输出。采用列向量梯度, 链式法则写成

$$\nabla L(\mathbf{x}) = J_f(\mathbf{x})^\top \nabla \ell(\mathbf{y})|_{\mathbf{y}=f(\mathbf{x})}.$$

局部线性映射在前向计算中按 J_f 作用, 在标量目标的反向计算中按转置 $J_f^\top$ 传回。这是后续反向传播的线性代数核心, 具体网络结构留到模型章节。

示例 3.27 从中间向量求回复合目标的梯度 令

$$f(x_1, x_2) = (x_1^2, x_1 x_2, x_2)^\top, \quad \ell(\mathbf{y}) = \frac{1}{2}(y_1^2 + y_2^2 + y_3^2).$$

f 从二维输入产生三维中间量, ℓ 再把三维中间量变成一个数。于是

$$\mathbf{J}_f = \begin{bmatrix} 2x_1 & 0 \\ x_2 & x_1 \\ 0 & 1 \end{bmatrix}, \quad \nabla \ell(\mathbf{y}) = \mathbf{y}.$$

在 $\mathbf{x} = (1, 2)^\top$ 处, $\mathbf{y} = (1, 2, 2)^\top$, 链式法则给出

$$\nabla L(1, 2) = \begin{bmatrix} 2 & 2 & 0 \\ 0 & 1 & 1 \end{bmatrix} \begin{bmatrix} 1 \\ 2 \\ 2 \end{bmatrix} = \begin{bmatrix} 6 \\ 4 \end{bmatrix}.$$

也可以把复合函数直接展开为 $L(x_1, x_2) = \frac{1}{2}(x_1^4 + x_1^2 x_2^2 + x_2^2)$, 求偏导得到 $\nabla L = (2x_1^3 + x_1 x_2^2, x_1^2 x_2 + x_2)^\top$, 在同一点仍为 $(6, 4)^\top$ 。两种计算处理同一个目标; 链式形式保留了中间映射, 可分别复用各层的导数。矩阵形状 $(2 \times 3)(3 \times 1) = 2 \times 1$ 也核对了梯度传递的次序。

下面用一个各输出分量相互影响的映射核对 Jacobian 矩阵。若要把任意实数评分变成正数且总和为 1 的权重, 可以先取指数再除以共同的总和。这就是 n 维归一化指数映射 (softmax)。对 $\mathbf{z} \in \mathbb{R}^n$, 令

$$s_i(\mathbf{z}) = \frac{e^{z_i}}{\sum_{k=1}^n e^{z_k}}, \quad i = 1, \dots, n.$$

记分母为 $Z = \sum_k e^{z_k}$ 。指数函数求导和商法则给出

$$\frac{\partial s_i}{\partial z_j} = \frac{\mathbb{I}\{i=j\}e^{z_i}Z - e^{z_i}e^{z_j}}{Z^2} = s_i(\mathbb{I}\{i=j\} - s_j).$$

因此整个 Jacobian 矩阵为

$$\mathbf{J}_s(\mathbf{z}) = \text{diag}(\mathbf{s}) - \mathbf{s}\mathbf{s}^\top. \quad (3.15)$$

对角项 $s_i(1 - s_i)$ 描述提高 z_i 对自身分量的影响, 非对角项 $-s_i s_j$ 来自共同分母: 提高一个坐标会压低其余归一化分量。每行元素之和为零, 这也与给所有 z_i 同时加同一常数不改变输出相符。

3.3.2.3 矩阵变量与微分计算

如果输入本身是矩阵, 逐条写出 mn 个偏导数会掩盖原有的矩阵乘法结构。矩阵 $\mathbf{X} \in \mathbb{R}^{m \times n}$ 可以看成 mn 个坐标组成的对象, 矩阵梯度则把这些一阶变化重新排回原来的形状。先固定 Frobenius 迹内积

$$\langle \mathbf{A}, \mathbf{B} \rangle_F = \text{tr}(\mathbf{A}^\top \mathbf{B})$$

其中 tr 是方阵对角元素之和, 所以这个内积也等于 $\sum_{i,j} \mathbf{A}_{i,j} \mathbf{B}_{i,j}$, 对应范数为 $\|\mathbf{H}\|_F = (\sum_{i,j} \mathbf{H}_{i,j}^2)^{1/2}$. 对标量函数 $f(\mathbf{X})$, 全微分要求 $f(\mathbf{X} + \mathbf{H}) = f(\mathbf{X}) + \text{d}f_{\mathbf{X}}(\mathbf{H}) + o(\|\mathbf{H}\|_F)$. 用这个内积定义矩阵梯度: 若一阶全微分能够写成

$$\text{d}f = \langle \nabla_{\mathbf{X}} f, \text{d}\mathbf{X} \rangle_F = \text{tr}((\nabla_{\mathbf{X}} f)^{\top} \text{d}\mathbf{X}), \quad (3.16)$$

则 $\nabla_{\mathbf{X}} f$ 与 $\mathbf{X}$ 形状相同。计算时可先用乘积法则展开微分, 再利用

$$\text{tr}(\mathbf{AB}) = \text{tr}(\mathbf{BA}), \quad \text{tr}(\mathbf{ABC}) = \text{tr}(\mathbf{BCA}),$$

把 $\text{d}\mathbf{X}$ 移动到末端。迹只允许循环移位, 不能任意交换相邻矩阵。

先考虑二次型 $q(\mathbf{x}) = \mathbf{x}^{\top} \mathbf{A} \mathbf{x}$, 其中 $\mathbf{A} \in \mathbb{R}^{d \times d}$ 固定。由乘积法则,

$$\begin{aligned} \text{d}q &= (\text{d}\mathbf{x})^{\top} \mathbf{A} \mathbf{x} + \mathbf{x}^{\top} \mathbf{A} \text{d}\mathbf{x} \\ &= \mathbf{x}^{\top} (\mathbf{A}^{\top} + \mathbf{A}) \text{d}\mathbf{x}. \end{aligned}$$

因此

$$\nabla_{\mathbf{x}} (\mathbf{x}^{\top} \mathbf{A} \mathbf{x}) = (\mathbf{A} + \mathbf{A}^{\top}) \mathbf{x}. \quad (3.17)$$

只有当 $\mathbf{A}$ 对称时才能化为 $2\mathbf{A}\mathbf{x}$ 。直接写成 $2\mathbf{A}\mathbf{x}$ 会悄然加入对称性条件。

对固定的 $\mathbf{A} \in \mathbb{R}^{m \times n}$, 令 $f(\mathbf{X}) = \text{tr}(\mathbf{A}^{\top} \mathbf{X})$ 。它的微分已经符合式 (3.16), 所以

$$\nabla_{\mathbf{X}} \text{tr}(\mathbf{A}^{\top} \mathbf{X}) = \mathbf{A}. \quad (3.18)$$

这个简单关系常用于从迹表达式中读出梯度。

若方阵 $\mathbf{X}$ 可逆, 由恒等式 $\mathbf{X}\mathbf{X}^{-1} = \mathbf{I}$ 取微分可得

$$(\text{d}\mathbf{X})\mathbf{X}^{-1} + \mathbf{X} \text{d}(\mathbf{X}^{-1}) = \mathbf{0}.$$

左乘 $\mathbf{X}^{-1}$ 后得到

$$\text{d}(\mathbf{X}^{-1}) = -\mathbf{X}^{-1}(\text{d}\mathbf{X})\mathbf{X}^{-1}. \quad (3.19)$$

两个 $\mathbf{X}^{-1}$ 位于扰动两侧, 不能合并成 $-\mathbf{X}^{-2}\text{d}\mathbf{X}$, 因为 $\text{d}\mathbf{X}$ 未必与 $\mathbf{X}^{-1}$ 交换。

再考虑行列式的对数。设 $\mathbf{X} \in \mathbb{R}^{d \times d}$ 正定, 因而 $\det \mathbf{X} > 0$ 且 $\log \det \mathbf{X}$ 有定义。Jacobi 行列式公式给出

$$\text{d} \det \mathbf{X} = \det(\mathbf{X}) \text{tr}(\mathbf{X}^{-1} \text{d}\mathbf{X}).$$

再应用标量对数的链式法则,

$$\text{d} \log \det \mathbf{X} = \text{tr}(\mathbf{X}^{-1} \text{d}\mathbf{X}), \quad \nabla_{\mathbf{X}} \log \det \mathbf{X} = \mathbf{X}^{-\top}. \quad (3.20)$$

正定矩阵对称, 所以 $\mathbf{X}^{-\top} = \mathbf{X}^{-1}$; 对一般可逆实矩阵, $\log \det \mathbf{X}$ 还需要 $\det \mathbf{X} > 0$, 而梯度应保留转置。这些梯度都由同一办法得到: 保留扰动的一阶项, 再用迹内积读出系数; 矩阵乘法的次序始终要保留。

示例 3.28 逆矩阵微分中的乘法次序 取 $\mathbf{X} = \text{diag}(2, 1)$, 扰动方向

$\mathbf{E} = \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}$ 。沿 $\mathbf{X} + t\mathbf{E}$ 求逆矩阵的导数为

$$-\mathbf{X}^{-1}\mathbf{E}\mathbf{X}^{-1} = \begin{bmatrix} 0 & -1/2 \\ -1/2 & 0 \end{bmatrix}.$$

若照搬标量规则而写成 $-\mathbf{X}^{-2}\mathbf{E}$, 会得到 $\begin{bmatrix} 0 & -1/4 \\ -1 & 0 \end{bmatrix}$, 连对称性都丢失。原路径在 0 附近由对称可逆矩阵组成, 其逆与导数也应对称; 这一结构检查能直接发现错误。矩阵变量沿给定方向微分时, 夹在两侧的逆矩阵不能随意移到同一侧。

3.3.2.4 导数界与位移控制

一点处的线性近似还不能控制一段有限位移。若沿整段路径的变化率都有上界, 中值定理才能把局部信息变成端点之间的误差界。若 $a < b$, $f: [a, b] \rightarrow \mathbb{R}$ 在 $[a, b]$ 上连续、在 (a, b) 上可导, 则 **中值定理** (mean value theorem) 保证存在 $c \in (a, b)$ 使

$$f(b) - f(a) = f'(c)(b - a). \quad (3.21)$$

所以, 若区间上 $|f'(x)| \leq L$, 便有 $|f(b) - f(a)| \leq L|b - a|$ 。这说明有界导数可以推出 Lipschitz 控制。多元标量函数也可沿线段使用一元中值定理: 当连接 $\mathbf{x}$ 与 $\mathbf{y}$ 的线段位于定义域且 f 在线段邻域可微时,

$$|f(\mathbf{y}) - f(\mathbf{x})| \leq \sup_{0 \leq t \leq 1} \|\nabla f(\mathbf{x} + t(\mathbf{y} - \mathbf{x}))\|_2 \|\mathbf{y} - \mathbf{x}\|_2.$$

这里控制的是标量函数值差。对向量值函数, 不能一般地断言存在一个共同的 c 让整个向量增量等于单个 Jacobian 矩阵乘以输入增量; 应使用积分形式或范数上界。

对向量输出, 用线性映射的最大放大倍数替代标量导数的绝对值。

定义 3.29 欧氏诱导算子范数 对矩阵 $\mathbf{A} \in \mathbb{R}^{s \times r}$, 由欧氏范数诱导的算子范数 (induced operator norm) 定义为

$$\|\mathbf{A}\|_{\text{op}} = \sup_{\mathbf{h} \neq \mathbf{0}} \frac{\|\mathbf{A}\mathbf{h}\|_2}{\|\mathbf{h}\|_2} = \sup_{\|\mathbf{h}\|_2=1} \|\mathbf{A}\mathbf{h}\|_2.$$

它表示线性映射对向量长度的最大放大倍数, 定义立即给出 $\|\mathbf{A}\mathbf{h}\|_2 \leq \|\mathbf{A}\|_{\text{op}} \|\mathbf{h}\|_2$ 。例如 $\mathbf{A} = \text{diag}(2, 1)$ 把第一坐标放大两倍、第二坐标保持不变, 故 $\|\mathbf{A}\|_{\text{op}} = 2$; 最大放大由第一坐标方向达到。下文 DG 与 J_G 均表示 G 的 Jacobian 矩阵。若映射 G 在包含 $\mathbf{y}'$ 到 $\mathbf{y}$ 线段的开邻域内连续可微, 可以沿线段使用一元中值定理, 得到

$$\|G(\mathbf{y}) - G(\mathbf{y}')\|_2 \leq \sup_{0 \leq t \leq 1} \|DG(\mathbf{y}' + t(\mathbf{y} - \mathbf{y}'))\|_{\text{op}} \|\mathbf{y} - \mathbf{y}'\|_2. \quad (3.22)$$

这个向量上界无需预先使用积分公式。若 $\mathbf{u} = G(\mathbf{y}) - G(\mathbf{y}') \neq \mathbf{0}$, 取单位向量 $\mathbf{v} = \mathbf{u}/\|\mathbf{u}\|_2$, 并沿线段定义标量函数 $\phi(t) = \mathbf{v}^T G(\mathbf{y}' + t(\mathbf{y} - \mathbf{y}'))$ 。中值定理给出某个 $\tau \in (0, 1)$, 使

$$\|\mathbf{u}\|_2 = \phi(1) - \phi(0) = \mathbf{v}^T DG(\mathbf{y}' + \tau(\mathbf{y} - \mathbf{y}'))(\mathbf{y} - \mathbf{y}').$$

对右侧使用欧氏内积与算子范数的上界便得到式 (3.22); $\mathbf{u} = \mathbf{0}$ 时该界直接成立。因此, 若一个区域包含其中任意两点之间的整条线段, 那么该区域上统一的导数范数上界可以作为 Lipschitz 常数。若这是一个把该区域映回自身的更新映射, 而且上界小于 1, 就得到第 3.2.3.1 节的压缩条件。

3.3.3 二阶导数与局部曲率

延续 $f(x) = x^3 - 3x$ 的例子, 一阶导数 $f'(x) = 3x^2 - 3$ 还随位置变化。再求一次导数, 得到 $f''(x) = 6x$, 所以 $f''(1/2) = 3$ 。在 $x_0 = 1/2$ 附近, 斜率向右移动时增大, 曲线向上弯; 这解释了真实值为何高于前节的切线预测。图 3.4 将切线和下面的二次修正放在同一幅曲线图上比较。加入二次项得到

$$T_2(h) = T_1(h) + \frac{1}{2}f''(x_0)h^2 = -\frac{11}{8} - \frac{9}{4}h + \frac{3}{2}h^2. \quad (3.23)$$

在 $h = 0.1$ 时, $T_2 = -1.585$, 与实际值 -1.584 只差 0.001。一阶导数回答此处沿给定方向增还是减, 二阶导数回答这个变化率怎样改变。下一节再用 Taylor 展开给出一阶和二阶余项的完整表达式。

一阶近似只保留函数的局部斜率。若还要判断这个斜率怎样随位置改变, 就需要 Hessian 矩阵 (Hessian matrix)。设 $f: \mathbb{R}^d \rightarrow \mathbb{R}$ 在 $\mathbf{x}$ 附近二阶可微, 定义

$$\nabla^2 f(\mathbf{x}) = \begin{bmatrix} \frac{\partial^2 f}{\partial x_1^2} & \cdots & \frac{\partial^2 f}{\partial x_1 \partial x_d} \\ \vdots & \ddots & \vdots \\ \frac{\partial^2 f}{\partial x_d \partial x_1} & \cdots & \frac{\partial^2 f}{\partial x_d^2} \end{bmatrix}.$$

若二阶偏导数在邻域内连续, 混合偏导数可以交换, Hessian 矩阵因而对称。对方向 $\mathbf{v}$, 二次型 $\mathbf{v}^\top \nabla^2 f(\mathbf{x}) \mathbf{v}$ 是沿直线 $t \mapsto f(\mathbf{x} + t\mathbf{v})$ 在 $t = 0$ 处的二阶导数。它衡量的不是函数值大小, 而是沿该方向的一阶斜率变化。

对二次函数

$$f(\mathbf{x}) = \frac{1}{2} \mathbf{x}^\top \mathbf{A} \mathbf{x} + \mathbf{b}^\top \mathbf{x} + c,$$

只有 $\mathbf{A}$ 的对称部分影响函数值。令 $\mathbf{H} = (\mathbf{A} + \mathbf{A}^\top)/2$, 则 $\nabla f(\mathbf{x}) = \mathbf{H} \mathbf{x} + \mathbf{b}$ 且 $\nabla^2 f(\mathbf{x}) = \mathbf{H}$ 。正特征值对应向上弯曲的方向, 负特征值对应向下弯曲的方向; 特征值绝对值相差很大时, 不同方向的尺度也相差很大。

3.3.4 Taylor 展开与余项控制

一阶导数给出切线, 二阶导数描述斜率的变化, 但近似不限于这两个阶数。Taylor 展开把函数在一点处的各阶导数组织成多项式, 并用余项记录被舍弃的变化。它承接前两节的导数计算, 回答“保留多少信息能得到多准确的局部近似”, 而不把展开限定为二阶公式。

回顾一元 Taylor 公式: 取非负整数 r , 若 f 在连接 x_0 与 $x_0 + h$ 的线段的开邻域上 $r+1$ 阶连续可微, 且 $h \neq 0$, 则存在两端之间的 ξ 使

$$f(x_0 + h) = \sum_{k=0}^r \frac{f^{(k)}(x_0)}{k!} h^k + \frac{f^{(r+1)}(\xi)}{(r+1)!} h^{r+1}. \quad (3.24)$$

约定 $f^{(0)} = f$, r 是所保留的最高次数。常数项记录当前函数值, 线性项记录斜率, 二次项记录曲率, 继续保留高阶项才得到更高阶近似。若沿这条线段 $|f^{(r+1)}| \leq M$, 余项的绝对值便不超过 $M|h|^{r+1}/(r+1)!$ 。所以“高阶近似更准确”还依赖扰动尺度与导数上界, 不能只比较多项式的次数。此处给出的是选取某个中间点的 Lagrange 余项; 若要保留整条线段上各位置的贡献, 第 3.4.5.1 节将由分部积分建立积分余项, 本节的极值判据并不依赖尚未建立的积分公式。

对前两节的 $f(x) = x^3 - 3x$, $x_0 = 1/2$, 三阶展开恰好为

$$f(x_0 + h) = -\frac{11}{8} - \frac{9}{4}h + \frac{3}{2}h^2 + h^3.$$

此处所有四阶及以上导数为零，没有继续舍弃的项。一阶近似 T_1 与二阶近似 T_2 分别舍弃 $\frac{3}{2}h^2 + h^3$ 和 h^3 。图 3.4 把两侧扰动放在同一尺度上比较，显示线性、二次近似怎样接近原曲线，并标出 $h = \pm 0.1$ 时的余项。




图 3.4 统一函数 $f(x) = x^3 - 3x$ 在 $x_0 = 1/2$ 处的两阶近似，记 $h = x - x_0$ 。(a) 蓝线为真函数，红虚线为切线近似 $T_1 = f(x_0) + f'(x_0)h$ ，黄点线加入二次项 $f''(x_0)h^2/2$ ，得到 T_2 。(b) 扣除各近似后的带符号余项分别为 $3h^2/2 + h^3$ 与 h^3 ，标出 $h = \pm 0.1$ 的精确结果。一阶导数确定切线，二阶导数补充局部曲率；余项的正负表示真值位于近似值的哪一侧。图为解析教学示例。

设连接 $\mathbf{x}$ 与 $\mathbf{x} + \mathbf{h}$ 的线段包含在一个开集内，并且 f 在该开集上二阶连续可微。对一元函数 $\phi(t) = f(\mathbf{x} + t\mathbf{h})$ 使用 Taylor 定理，存在 $\theta \in (0, 1)$ 使

$$f(\mathbf{x} + \mathbf{h}) = f(\mathbf{x}) + \nabla f(\mathbf{x})^\top \mathbf{h} + \frac{1}{2} \mathbf{h}^\top \nabla^2 f(\mathbf{x} + \theta \mathbf{h}) \mathbf{h}. \quad (3.25)$$

由 Hessian 矩阵的连续性，当 $\mathbf{h} \rightarrow \mathbf{0}$ 时，中间点处的二阶项可以换成基点处的二阶项，并把差异归入更小阶的余项：

$$f(\mathbf{x} + \mathbf{h}) = f(\mathbf{x}) + \nabla f(\mathbf{x})^\top \mathbf{h} + \frac{1}{2} \mathbf{h}^\top \nabla^2 f(\mathbf{x}) \mathbf{h} + o(\|\mathbf{h}\|_2^2). \quad (3.26)$$

式 (3.26) 是局部结论。若要在一个区域内给出统一余项界，还需控制该区域上的 Hessian 矩阵连续性或 Lipschitz 常数，不能仅凭一点处的二阶导数。

有了余项控制，才能由近似多项式判断函数本身的极值。局部极小点是指某个邻域内所有函数值都不小于该点的值；严格局部极小还要求其他点的值严格更大。设 $\mathbf{x}^*$ 是开集内部的局部极小点，且 f 在该点可微。对每

个方向 $\mathbf{v}$ 考察 $f(\mathbf{x}^* + t\mathbf{v})$, 一元函数的必要条件给出 $\nabla f(\mathbf{x}^*)^\top \mathbf{v} = 0$ 。这对所有 $\mathbf{v}$ 成立, 因此

$$\nabla f(\mathbf{x}^*) = \mathbf{0}. \quad (3.27)$$

若 f 还在该点二阶可微, 同样沿任意方向使用一元二阶必要条件, 可得

$$\mathbf{v}^\top \nabla^2 f(\mathbf{x}^*) \mathbf{v} \geq 0 \quad \text{对所有 } \mathbf{v}, \quad (3.28)$$

梯度为零的点称为驻点。上面的二阶条件则要求 Hessian 矩阵半正定; 局部极大点对应半负定。这些只是必要条件: $f(x) = x^4$ 与 $f(x) = -x^4$ 在 0 处分别有严格局部极小值和严格局部极大值, 二者的二阶导数却都为零; $f(x) = x^3$ 在 0 处的一阶导数和二阶导数也都为零, 却没有极值。Hessian 矩阵半正定或半负定本身不能决定驻点类型。

正定 Hessian 矩阵给出更强的充分条件。若 f 在 $\mathbf{x}^*$ 的某个邻域内二阶连续可微, $\nabla f(\mathbf{x}^*) = \mathbf{0}$ 且 $\nabla^2 f(\mathbf{x}^*)$ 正定, 则其最小特征值为某个 $\lambda > 0$ 。由 Hessian 矩阵的连续性, 充分靠近 $\mathbf{x}^*$ 时, 任意方向上的二次型仍至少为 $(\lambda/2)\|\mathbf{h}\|_2^2$ 。用式 (3.25) 的中间点表达式, 即可把这个曲率下界变成函数数值下界; 具体地, 充分靠近时有

$$f(\mathbf{x}^* + \mathbf{h}) - f(\mathbf{x}^*) \geq \frac{\lambda}{4}\|\mathbf{h}\|_2^2 > 0$$

对充分小的非零 $\mathbf{h}$ 成立, 故 $\mathbf{x}^*$ 是严格局部极小点。负定情形给出严格局部极大点。

若驻点处 Hessian 矩阵既有正特征值又有负特征值, 沿相应特征向量的小扰动会使函数值分别增加和减小, 该点称为鞍点 (saddle point)。例如 $f(x, y) = x^2 - y^2$ 的原点就是鞍点。若 Hessian 矩阵仅半正定或含零特征值, 二阶判据可能没有结论, 必须查看更高阶项或函数的其他结构。上述必要条件还假定点位于无约束开集内部; 边界极小点的梯度可以不为零, 受约束问题需要后续章节的可行方向与乘子条件。

3.3.5 隐函数与解的敏感性

链式法则计算已给定映射的变化; 方程 $F(\mathbf{x}, \mathbf{y}) = 0$ 却还没有直接给出 $\mathbf{y}$ 关于 $\mathbf{x}$ 的函数。需要先证明局部解分支存在、唯一且可微, 才能对它求导。前面的导数位移界与本章压缩定理现在共同提供这一保证; 驻点方程随后把解分支用于参数变化下的敏感性分析。

显式关系 $\mathbf{y} = \varphi(\mathbf{x})$ 直接给出输入如何映射到输出, 方程 $F(\mathbf{x}, \mathbf{y}) = 0$ 却只规定二者必须共同满足的约束。例如 $F(x, y) = y^2 - x = 0$ 在 $x > 0$ 附近有 $y = \sqrt{x}$ 和 $y = -\sqrt{x}$ 两支, 若不先指定所考察的解, 方程并不定义唯一函数。更糟的是, 在 $(x, y) = (0, 0)$ 附近, 两支相交且 $\partial F / \partial y = 2y = 0$, 不能把 y 稳定地看作 x 的可微函数。

定理 3.30 隐函数定理 设 $F: \mathbb{R}^p \times \mathbb{R}^m \rightarrow \mathbb{R}^m$ 在 $(\mathbf{a}, \mathbf{b})$ 的某个开邻域内连续可微, $F(\mathbf{a}, \mathbf{b}) = \mathbf{0}$, 并且关于待解变量的 Jacobian 矩阵

$$D_{\mathbf{y}}F(\mathbf{a}, \mathbf{b}) \in \mathbb{R}^{m \times m}$$

可逆. 则存在 $\mathbf{a}$ 与 $\mathbf{b}$ 的邻域 U, V , 以及唯一的连续可微函数 $\varphi: U \rightarrow V$, 使 $\varphi(\mathbf{a}) = \mathbf{b}$, 并且对所有 $(\mathbf{x}, \mathbf{y}) \in U \times V$ 都有

$$F(\mathbf{x}, \mathbf{y}) = \mathbf{0} \iff \mathbf{y} = \varphi(\mathbf{x}).$$

其 Jacobian 矩阵满足

$$D\varphi(\mathbf{x}) = -[D_{\mathbf{y}}F(\mathbf{x}, \varphi(\mathbf{x}))]^{-1} D_{\mathbf{x}}F(\mathbf{x}, \varphi(\mathbf{x})). \quad (3.29)$$

证明. 为证明定理 3.30 的存在性, 先把方程改写为局部压缩迭代. 记

$$\mathbf{A} = D_{\mathbf{y}}F(\mathbf{a}, \mathbf{b}), \quad T_{\mathbf{x}}(\mathbf{y}) = \mathbf{y} - \mathbf{A}^{-1}F(\mathbf{x}, \mathbf{y}).$$

$F(\mathbf{x}, \mathbf{y}) = \mathbf{0}$ 当且仅当 $\mathbf{y}$ 是 $T_{\mathbf{x}}$ 的不动点. 并且

$$D_{\mathbf{y}}T_{\mathbf{x}}(\mathbf{y}) = \mathbf{I} - \mathbf{A}^{-1}D_{\mathbf{y}}F(\mathbf{x}, \mathbf{y}),$$

它在 $(\mathbf{a}, \mathbf{b})$ 处为零. 由导数连续性, 可以选择闭球 $B = \{\mathbf{y} : \|\mathbf{y} - \mathbf{b}\|_2 \leq r\}$ 和 $\mathbf{a}$ 的邻域 U , 使

$$\sup_{\mathbf{x} \in U, \mathbf{y} \in B} \|D_{\mathbf{y}}T_{\mathbf{x}}(\mathbf{y})\|_{\text{op}} \leq q < 1. \quad (3.30)$$

沿 $\mathbf{y}$ 方向使用式 (3.22) 可知, 每个 $T_{\mathbf{x}}$ 在 B 上都是同一因子 q 的压缩映射.

还必须核对自映射. 因为 $T_{\mathbf{a}}(\mathbf{b}) = \mathbf{b}$ 且 $T_{\mathbf{x}}(\mathbf{b})$ 关于 $\mathbf{x}$ 连续, 可进一步缩小 U , 使

$$\|T_{\mathbf{x}}(\mathbf{b}) - \mathbf{b}\|_2 \leq \frac{1-q}{2}r.$$

于是对 $\mathbf{y} \in B$,

$$\|T_{\mathbf{x}}(\mathbf{y}) - \mathbf{b}\|_2 \leq q\|\mathbf{y} - \mathbf{b}\|_2 + \frac{1-q}{2}r \leq \frac{1+q}{2}r < r.$$

所以 $T_{\mathbf{x}}(B)$ 包含在 B 的内部 V 中. 闭球 B 在有限维欧氏空间中完备, Banach 定理便对每个 $\mathbf{x} \in U$ 给出唯一不动点 $\varphi(\mathbf{x}) \in V$. 若 $(\mathbf{x}, \mathbf{y}) \in U \times V$ 且 $F(\mathbf{x}, \mathbf{y}) = \mathbf{0}$, 则 $\mathbf{y} \in B$ 也是 $T_{\mathbf{x}}$ 的不动点, 唯一性迫使 $\mathbf{y} = \varphi(\mathbf{x})$. 这证明了定理所述的局部存在与零点集合的逐点唯一性.

还需说明所得解随参数连续可微. 把 U 进一步缩小为开球, 并使 $\bar{U} \times B$ 包含在原定义域内; 这个集合紧致, 关于 $\mathbf{x}$ 的导数连续, 故有统一范数上

界 L 。对 $\mathbf{x}, \mathbf{x}' \in U$ ，两点间的线段仍在 U 内，式 (3.22) 可用于 $T_{\mathbf{x}}(\mathbf{y})$ 的参数变化。利用两个不动点关系，

$$\|\varphi(\mathbf{x}) - \varphi(\mathbf{x}')\|_2 \leq q\|\varphi(\mathbf{x}) - \varphi(\mathbf{x}')\|_2 + L\|\mathbf{x} - \mathbf{x}'\|_2,$$

移项得到 $\|\varphi(\mathbf{x}) - \varphi(\mathbf{x}')\|_2 \leq L\|\mathbf{x} - \mathbf{x}'\|_2/(1-q)$ ，故 φ 局部 Lipschitz 连续。令 $\mathbf{h} \rightarrow \mathbf{0}$ 并记 $\mathbf{k} = \varphi(\mathbf{x} + \mathbf{h}) - \varphi(\mathbf{x})$ ，前述界给出 $\|\mathbf{k}\|_2 = O(\|\mathbf{h}\|_2)$ 。对恒等式

$$F(\mathbf{x} + \mathbf{h}, \varphi(\mathbf{x}) + \mathbf{k}) - F(\mathbf{x}, \varphi(\mathbf{x})) = \mathbf{0}$$

作一阶展开，得到

$$\mathbf{D}_{\mathbf{x}}F \mathbf{h} + \mathbf{D}_{\mathbf{y}}F \mathbf{k} + o(\|\mathbf{h}\|_2) = \mathbf{0}.$$

展开中的 Jacobian 均在 $(\mathbf{x}, \varphi(\mathbf{x}))$ 处取值，联合扰动的余项 $o(\|(\mathbf{h}, \mathbf{k})\|_2)$ 因 $\|\mathbf{k}\|_2 = O(\|\mathbf{h}\|_2)$ 成为 $o(\|\mathbf{h}\|_2)$ 。基点的 $\det \mathbf{A} \neq 0$ ，行列式又是矩阵元素的连续函数，所以邻域足够小时 $\mathbf{D}_{\mathbf{y}}F$ 仍可逆。于是

$$\mathbf{k} = -(\mathbf{D}_{\mathbf{y}}F)^{-1}\mathbf{D}_{\mathbf{x}}F \mathbf{h} + o(\|\mathbf{h}\|_2).$$

这证明 φ 可微并给出式 (3.29)；各 Jacobian 矩阵连续又保证 $\mathbf{D}\varphi$ 连续。至此，隐函数定理中的存在、局部唯一与导数公式都已得到说明。证明中特别核对了自映射和统一压缩条件，只有形式上的固定点改写并不足够。■

隐函数的存在与可微性建立以后，还可以直接从链式法则理解导数公式。对恒等式 $F(\mathbf{x}, \varphi(\mathbf{x})) = \mathbf{0}$ 应用链式法则，得到

$$\mathbf{D}_{\mathbf{x}}F + \mathbf{D}_{\mathbf{y}}F \mathbf{D}\varphi = \mathbf{0}.$$

左乘 $\mathbf{D}_{\mathbf{y}}F$ 的逆即得式 (3.29)。乘法次序由矩阵维度决定，不能把逆矩阵随意移到右侧。

考虑依赖参数 θ 的无约束目标 $q(z, \theta)$ 。若局部最优解 $z^*(\theta)$ 位于定义域内部，它满足驻点方程

$$F(\theta, z) = \frac{\partial q}{\partial z}(z, \theta) = 0.$$

若 q 二阶连续可微，且 $\partial^2 q / \partial z^2$ 在所考察解处非零，隐函数定理给出该驻点的局部唯一分支。这并不自动说明它是全局最优解；还要由曲率或其他结构核对最优性。

示例 3.31 参数二次目标中的解导数与包络导数 对 $\theta > -1$, 令

$$q(z, \theta) = \frac{1}{2}(1 + \theta)z^2 - \theta z.$$

因为 $\theta > -1$, 配方得到

$$q(z, \theta) = \frac{1 + \theta}{2} \left(z - \frac{\theta}{1 + \theta} \right)^2 - \frac{\theta^2}{2(1 + \theta)}.$$

平方项的系数为正, 所以唯一驻点就是全局最小点。驻点方程为

$$F(\theta, z) = (1 + \theta)z - \theta = 0.$$

隐式求导给出

$$\frac{dz^*}{d\theta} = -\frac{\partial F / \partial \theta}{\partial F / \partial z} = -\frac{z^* - 1}{1 + \theta}.$$

直接消元得到

$$z^*(\theta) = \frac{\theta}{1 + \theta}, \quad \frac{dz^*}{d\theta} = \frac{1}{(1 + \theta)^2},$$

两种计算一致。

最优值 $V(\theta) = q(z^*(\theta), \theta)$ 的链式求导为

$$V'(\theta) = \frac{\partial q}{\partial z} \frac{dz^*}{d\theta} + \frac{\partial q}{\partial \theta}.$$

在内部驻点, 第一项因 $\partial q / \partial z = 0$ 消失, 所以

$$V'(\theta) = \left. \frac{\partial q}{\partial \theta} \right|_{z=z^*(\theta)} = \frac{1}{2}(z^*)^2 - z^*. \quad (3.31)$$

另一方面, 直接代回可得

$$V(\theta) = -\frac{\theta^2}{2(1 + \theta)}, \quad V'(\theta) = -\frac{\theta(\theta + 2)}{2(1 + \theta)^2},$$

与式 (3.31) 一致。

式 (3.31) 体现了包络定理 (envelope theorem) 的基本机制: 最优值的一阶变化不需要显式乘上最优解导数, 因为目标对决策变量的一阶导数在内部最优点为零。但解导数本身并未消失; 若关心参数变化后 z^* 怎样移动, 仍要使用隐式求导。边界解、不可微目标、多重最优解或受约束问题不能直接套用这个简单版本, 后续最优化章节会加入相应条件。

3.3.6 非光滑函数与广义梯度

前面的微分公式都有可微性条件。遇到尖点、阈值或离散选择时，需要重新判断所使用的变化信息：真实导数在何处存在，哪些广义导数仍有数学含义，算法又可能另外指定什么更新信号。下面从真实函数的性质进入广义梯度，再区分人为替代规则，避免把三者混写。

函数 $|x|$ 在 $x \neq 0$ 处导数为 $\text{sign}(x)$ ，在 0 处左右导数不同。ReLU 函数 $\max\{0, x\}$ 把负输入截为零、正输入保持不变，也只在 0 处不可微。由于单点是 Lebesgue 零测集，它们都几乎处处可导，但“几乎处处有导数”并没有为例外点指定导数值。

阈值函数 $\mathbb{I}\{x \geq 0\}$ 在 $x \neq 0$ 处导数为 0，在 0 处不连续且不可微。若机械地使用几乎处处导数，反向传播得到的信号几乎处处为零，这无法表达跨过阈值会改变输出。重置、取整和离散选择也有类似问题：前向映射的真实局部导数可能不存在或不能提供有用方向。

凸函数的不可微点可以用凸次梯度处理，其正式定义与最优性条件见第 4.3.1 节。凸次梯度依赖全局仿射下界，并非“随便给不可微点填一个导数”；对于一般非凸函数，还需要区分其他广义导数概念。

定义 3.22 已经给出局部 Lipschitz 条件。Rademacher 定理说明，满足该条件的函数关于 Lebesgue 测度几乎处处可微；这里回用第 3.1 节的零测集约定，定理仍没有为例外点指定唯一梯度。

一种适用于局部 Lipschitz 函数的扩展是 Clarke 广义梯度（Clarke generalized gradient）：它收集从邻近可微点趋近时出现的梯度极限，再由这些向量构成一组候选方向。非负权重且权重和为 1 的有限加权平均称为凸组合；允许所有这样的组合，并纳入这些组合能够逼近的极限向量，就得到闭凸包。

定义 3.32 Clarke 广义梯度 设 $U \subseteq \mathbb{R}^d$ 为开集， $f : U \rightarrow \mathbb{R}$ 局部 Lipschitz。对内点 $\mathbf{x} \in U$ ， f 在 $\mathbf{x}$ 处的 Clarke 广义梯度定义为

$$\partial^\circ f(\mathbf{x}) = \overline{\text{conv}} \left\{ \lim_{k \rightarrow \infty} \nabla f(\mathbf{x}_k) : \begin{array}{l} \mathbf{x}_k \in U, \quad \mathbf{x}_k \rightarrow \mathbf{x}, \\ f \text{ 在每个 } \mathbf{x}_k \text{ 处可微,} \\ \text{且上述梯度极限存在} \end{array} \right\}.$$

其中 conv 表示取所有有限凸组合，横线表示在 $\mathbb{R}^d$ 中取闭包，即把集合内序列的所有极限点也纳入。

对局部 Lipschitz 凸函数，Clarke 广义梯度与第 4.3.1 节定义的凸次梯度集合一致；对一般非凸局部 Lipschitz 函数，前者仍由邻近可微点的梯度极限构造，不再表示全局仿射下界。阈值函数在跳点附近不连续，因而不

是局部 Lipschitz 函数，不能直接套用这一构造。例如 $f(x) = -|x|$ 在原点左右两侧的导数分别为 1 与 -1，故其 Clarke 广义梯度是 $[-1, 1]$ ，包含零；然而原点是局部最大点。若把凸次梯度的全局下界定义硬用于此处，正半轴要求斜率 $g \leq -1$ ，负半轴却要求 $g \geq 1$ ，不存在满足条件的 g 。同样的候选区间 $[-1, 1]$ ，在 $|x|$ 上可以刻画全局最小点，在 $-|x|$ 上却不提供这样的保证。这说明广义梯度中含零只是相应的驻点条件，仍要核对所用定义和函数结构。图 3.5 选取两者共有的候选 $g = 0$ 。在 $|x|$ 中，它给出有效的全局下界；在 $-|x|$ 中，原函数反而处处不高于这条线。局部斜率的凸包抹去了两边斜率出现的次序，不能替代函数整体上下关系。




图 3.5 同一广义驻点条件的不同含义。蓝线分别为 $|x|$ 与 $-|x|$ ，红虚线为原点处候选斜率 $g = 0$ 对应的直线。两图在原点的 Clarke 广义梯度均为 $[-1, 1]$ ，却分别形成局部最小点与局部最大点；只有左图红线是全局仿射下界。两图共用坐标尺度，由解析式生成。

在含阈值或脉冲事件的模型中，常保留离散前向映射，却在反向计算时将其导数替换成某个平滑且非零的函数。这种信号称为替代梯度 (surrogate gradient)。它是算法人为指定的近似更新方向，不自动等于前向映射的经典导数，也通常不满足凸次梯度的不等式。因此使用时应分别写清前向函数、反向替代函数及其尺度，不能把训练规则描述成对原离散函数的精确求导。

中心差分

$$\frac{f(x + \varepsilon) - f(x - \varepsilon)}{2\varepsilon}$$

只能检验实际代入的函数 f 在尺度 ε 附近怎样变化。若程序反向传播使用替代梯度，而数值差分计算离散前向函数，两者本来就不是同一个导数对象；不一致不必然说明程序实现错误。

3.4 函数的可测性与整体关系

局部变化研究一个位置附近的输出增量；整体累计还要知道每个范围占多少权重。第3.1节已建立可测集合族与测度，现在把函数的取值与这些范围连接起来：可测性保证按取值分组后仍能赋权，积分再把每组贡献累计为总量。整体关系还包括变量之间怎样共同累计，以及局部导数怎样转化为边界贡献。

3.4.1 函数的可测性

测度只知道集合的大小，还不知道函数在集合上贡献多少。把函数按取值分组后，对于取相同函数值的一组输入，这组贡献就是“该取值乘以这组输入的测度”。因此，在写积分之前，要保证这些取值集合属于已经允许测量的范围。

可测性说的是函数与这些测量范围是否相容：对输出值提出一个可测的条件，满足条件的输入也应组成可测集合。这里需要的是集合的原像，并不要求函数有逆函数。

定义 3.33 可测函数 给定可测空间 $(X, \mathcal{A})$ 与 $(Y, \mathcal{B})$ 。若映射 $f : X \rightarrow Y$ 满足

$$B \in \mathcal{B} \implies f^{-1}(B) = \{x \in X : f(x) \in B\} \in \mathcal{A},$$

则称 f 为从 $(X, \mathcal{A})$ 到 $(Y, \mathcal{B})$ 的可测函数 (measurable function)。对取值于 $\mathbb{R}$ 或 $\overline{\mathbb{R}} = [-\infty, \infty]$ 的函数，目标空间取 Borel σ 代数；此时可测性等价于

$$\{x \in X : f(x) > a\} \in \mathcal{A} \quad \text{对每个 } a \in \mathbb{R} \text{ 成立.}$$

阈值条件之所以足够，是因为这些半直线能生成目标空间的 Borel σ 代数，而原像保持补集与可数并。它保证按函数值分层得到的集合都能取得测度。可测性依赖指定的 σ 代数，并不依赖这些集合具体有多大权重。例如在 $X = \{a, b\}$ 上只允许 $\mathcal{A} = \{\emptyset, X\}$ 时， $f(a) = 0$ 、 $f(b) = 1$ 不可测：阈值 $1/2$ 选出 $\{b\}$ ，不在 $\mathcal{A}$ 中。把 $\mathcal{A}$ 改为所有子集后，同一个函数就可测。

连续性比较输入与输出的距离，本身不以可测性为先决条件。若两端采用 Borel σ 代数，连续映射自动可测，因为开集的原像仍是开集；若任意指定其他 σ 代数，则不能只凭连续性保证可测。反向也不成立。例如 $[0, 1]$ 上有理数的指示函数 $\mathbb{I}_{\mathbb{Q} \cap [0, 1]}$ 可测，因为有理数集合是可数个单点的并，但它在每一点都不连续：任意小邻域内同时有有理数和无理数，函数值在 1 和 0 之间跳变。可测性只保证取值分组可以测量，不保证图像平滑，也不保证积分有限。可测函数列的逐点极限存在时仍可测，可数族可测函数的

逐点上确界和下确界也可测。这些封闭性使下面的阶梯逼近能够留在同一套积分框架中。

这些极限的可测性可以直接回到集合运算，而不依赖尚未建立的积分定理。对可测实函数列，

$$\begin{aligned}\{x : \sup_n f_n(x) > a\} &= \bigcup_n \{x : f_n(x) > a\}, \\ \{x : \inf_n f_n(x) < a\} &= \bigcup_n \{x : f_n(x) < a\}.\end{aligned}$$

因此上确界、下确界可测；再用 $\liminf_n f_n = \sup_N \inf_{n \geq N} f_n$ ，得到下极限可测，逐点极限存在时就是它。有限加法、绝对值、最大值等连续运算也保持实函数的可测性： (f, g) 的矩形原像是两个可测原像的交，而实平面的开集可写成可数个有理端点矩形的并。这为后面按 $\{f > a\}$ 分层、取正负部分和比较 f, g 提供了集合依据。

例如在 $X = \mathbb{R}$ 上采用通常距离，却只允许 $\mathcal{A} = \{\emptyset, \mathbb{R}\}$ ，目标采用 Borel 集合族，则连续函数 $f(x) = x$ 不是从 $(X, \mathcal{A})$ 到目标可测空间的可测函数：开区间 $(0, 1)$ 的原像不属于 $\mathcal{A}$ 。因此可测、连续与可积需要分别核对其结构与条件。即使固定 Lebesgue 测度，连续也不等于可积： $f(x) = 1/x$ 在 $(0, 1)$ 上连续且可测，总积分却为无穷。相反，有理数指示函数虽处处不连续，积分却为零。下面构造积分后，再核对这些大小关系；可测性负责“能否按取值赋权”，可积性负责“绝对贡献是否有限”。

3.4.2 积分的构造与可积性

3.4.2.1 简单函数与非负积分

一般函数可能取无穷多个不同的值，先从只取有限多个值的可测函数开始。它们可以按每个取值对应的集合分组，使积分直接退化为有限加权和。

定义 3.34 简单函数及其积分 在可测空间 $(X, \mathcal{A})$ 上，只取有限多个实数值的可测函数称为简单函数 (simple function)。非负简单函数可以表示为

$$s(x) = \sum_{j=1}^m a_j \mathbb{I}_{A_j}(x), \quad a_j \in [0, \infty), \quad A_j \in \mathcal{A},$$

其中 A_j 两两不交， $\mathbb{I}_{A_j}$ 在 A_j 上取 1、其余处取 0。给定测度 μ ，其积分定义为

$$\int_X s d\mu = \sum_{j=1}^m a_j \mu(A_j). \quad (3.32)$$

约定 $0 \cdot \infty = 0$, 并允许积分取 $+\infty$ 。

同一个简单函数可能有不同的分组表示; 把这些表示按所有取值集合的交集细分成共同的两两不交集合后, 有限可加性给出相同的和, 因此式 (3.32) 不依赖具体表示。同样的共同细分还给出简单函数的大小关系与非负线性: 若 $s \leq t$, 则 $\int s \leq \int t$; 若 $\alpha, \beta \geq 0$, 则 $\int(\alpha s + \beta t) = \alpha \int s + \beta \int t$ 。这些结论只涉及同一组可测块上的有限加权和, 尚未对一般函数交换极限和积分。

例如对 $[0, 1]$ 上的 $f(x) = x$, 用两段阶梯从下方近似: 前半段取 0, 后半段取 $1/2$, 其积分为 $1/4$ 。细分成四段并取每段左端点的函数值, 积分变成 $(0 + 1/4 + 1/2 + 3/4)/4 = 3/8$; 继续细分, 阶梯越来越接近原函数, 面积趋于熟悉的 $1/2$ 。这里每个阶段都只计算有限个“取值 $\times$ 集合长度”, 极限才把它们接成一般积分。

这一做法不限于区间。每个非负可测函数 f 都能由一系列非负简单函数从下方逐点逼近。对 $n \geq 1$, 一个明确的构造是

$$s_n(x) = \sum_{k=0}^{n2^n-1} \frac{k}{2^n} \mathbb{I}_{\{k2^{-n} \leq f(x) < (k+1)2^{-n}\}} + n \mathbb{I}_{\{f(x) \geq n\}}. \quad (3.33)$$

它先把函数值截断在 n , 再向下舍入到间距为 2^{-n} 的格点。截断高度随 n 增加, 格点也逐次细化, 所以 $0 \leq s_n \leq s_{n+1} \leq f$ 。若 $f(x) < \infty$, 当 $n > f(x)$ 时还有 $0 \leq f(x) - s_n(x) < 2^{-n}$; 若 $f(x) = +\infty$, 则 $s_n(x) = n$ 。因此 $s_n(x) \uparrow f(x)$ 对每个 x 成立。每个下方阶梯的积分都可以直接用有限和计算。我们希望一般非负函数的积分能纳入所有这样的下方近似, 因此把它定义为这些简单函数积分的上确界。图 3.6 把同一构造用于 $f(x) = x^2$ 。等距划分的是函数值, 对应的输入区间宽度不必相等; 每块黄色面积仍是一个取值乘以它的原像集合的测度。随着取值间距缩小, 下方阶梯留下的空隙逐渐减小。

定义 3.35 非负函数的 Lebesgue 积分 在测度空间 $(X, \mathcal{A}, \mu)$ 上, 非负可测函数 $f: X \rightarrow [0, \infty]$ 的积分定义为

$$\int_X f \, d\mu = \sup \left\{ \int_X s \, d\mu : 0 \leq s \leq f, s \text{ 为简单函数} \right\}. \quad (3.34)$$

这里允许结果为 $+\infty$ 。

这个定义不要求把定义域切成连续小区间, 而是按函数值分层, 所以能自然处理极限和零测例外。式 (3.33) 给出的阶梯也可用来计算这个上确界; 下面的单调收敛定理说明, 任意这样的递增逼近都能计算这个上确界。




图 3.6 按取值分层的简单函数逼近。两图都使用式 (3.33) 的构造，分别取 $n = 2$ 和 $n = 4$ ；本例中高度截断不起作用。黄色阶梯下的面积是有限加权和，目标曲线下的面积为 $1/3$ 。两图共用坐标尺度。

3.4.2.2 单调逼近与积分性质

非负积分定义直接保留大小关系：若 $0 \leq f \leq g$ ，每个不超过 f 的简单函数也不超过 g ，所以 $\int f d\mu \leq \int g d\mu$ 。它也继承零测修改不变性。设 N 可测且 $\mu(N) = 0$ ， f, g 可测非负并在 $X \setminus N$ 相等。任取简单函数 $0 \leq s \leq f$ ，去掉 N 上的部分得到 $s|_{X \setminus N} \leq g$ ，且简单函数积分没有改变；取上确界得到 $\int f \leq \int g$ ，反向同理。这里没有用一般积分的线性，只用了简单函数的有限和。修改后的函数仍须可测；在未完备测度空间中，不能在零测集上任意修改而省略这项要求。

一种防止总量在逼近中消失的方式，是只让非负贡献逐步增加。它正好对应上面的下方阶梯。记 $f_n(x) \uparrow f(x)$ 表示每个固定 x 处的数列单调增加且趋于 $f(x)$ ；允许忽略零测例外时，例外须包含在同一个可测零测集中。下面把阶梯逼近推广到任意递增的非负可测函数列³。

³ G. B. Folland, *Real Analysis: Modern Techniques and Their Applications*, Wiley, 1999, 2nd ed.

定理 3.36 单调收敛定理 设 $f_n, f : X \rightarrow [0, \infty]$ 可测，且 $f_n(x) \uparrow f(x)$ 几乎处处，则

$$\lim_{n \rightarrow \infty} \int_X f_n d\mu = \int_X f d\mu.$$

两边都允许取 $+\infty$ 。

证明. 把单调性或收敛关系失效的可测零测集并为 N , 并将 f_n 与 f 在 N 上都改为 0. 修改后的函数仍可测且积分不变, 所以可假定 $f_n \uparrow f$ 逐点成立. 由 $0 \leq f_n \leq f$, 积分序列单调不减且

$$L := \lim_{n \rightarrow \infty} \int f_n d\mu \leq \int f d\mu.$$

还需证明反向不等式. 任取满足 $0 \leq s \leq f$ 的简单函数, 将它写为 $s = \sum_{j=1}^m a_j \mathbb{I}_{E_j}$, 其中 $a_j > 0$ 且 E_j 两两不交. 固定 $c \in (0, 1)$, 定义

$$E_{j,n} = E_j \cap \{x : f_n(x) \geq ca_j\}.$$

由于 $f_n \uparrow f$ 且 $f \geq a_j$ 于 E_j , 有 $E_{j,n} \uparrow E_j$. 第 3.1.2.2 节已由可数可加性证明测度对递增集合连续, 故 $\mu(E_{j,n}) \uparrow \mu(E_j)$. 同时

$$f_n \geq c \sum_{j=1}^m a_j \mathbb{I}_{E_{j,n}},$$

从而

$$L \geq \lim_{n \rightarrow \infty} c \sum_{j=1}^m a_j \mu(E_{j,n}) = c \int s d\mu.$$

先令 $c \uparrow 1$, 再对所有 $0 \leq s \leq f$ 的简单函数取上确界. 根据非负积分的定义 (3.34), $L \geq \int f d\mu$. 与前一不等式合并即得结论. ■

非负性避免正负无穷相消, 单调性则保证已经积累的质量不会在后续消失. 定理不要求存在一个可积的统一上界, 也不要求各 $\int f_n$ 有限.

单调收敛已经说明递增逼近怎样保留总量. 积分还应继承有限和的两个基本规律: 贡献增加时总量不能减少, 非负线性组合的总量等于各总量的同一线性组合. 下面给出它们在一般测度空间中的版本; 需要证明的是, 把简单函数推广到可能无界的一般函数后, 这些规律仍然成立.

引理 3.37 非负积分的线性与单调性 设 $f, g : X \rightarrow [0, \infty]$ 可测, $\alpha, \beta \geq 0$. 若 $f \leq g$ 几乎处处, 则

$$\int_X f d\mu \leq \int_X g d\mu.$$

此外, 在 $0 \cdot \infty = 0$ 的约定下,

$$\int_X (\alpha f + \beta g) d\mu = \alpha \int_X f d\mu + \beta \int_X g d\mu.$$

证明. 对 $f \leq g$ 几乎处处的情形, 集合 $N = \{x : f(x) > g(x)\}$ 可测且 $\mu(N) = 0$. 把 f 在 N 上改为 0 得到可测函数 $\tilde{f}$, 其积分与 f 相同, 并且

逐点满足 $\tilde{f} \leq g$ 。此时每个满足 $0 \leq s \leq \tilde{f}$ 的简单函数也满足 $s \leq g$ ；在式 (3.34) 中取上确界便得到单调性。

还需把简单函数的线性提升到一般非负函数。前面的单调收敛定理 3.36 已保证：非负可测函数递增逼近其极限时，积分也递增趋于极限的积分。现在分别取非负简单函数 $s_n \uparrow f$ 和 $t_n \uparrow g$ ，则 $\alpha s_n + \beta t_n \uparrow \alpha f + \beta g$ 。对这三个函数列应用单调收敛定理，结合简单函数的线性性，即得

$$\int_X (\alpha f + \beta g) d\mu = \lim_{n \rightarrow \infty} \left(\alpha \int_X s_n d\mu + \beta \int_X t_n d\mu \right),$$

右侧正是结论中的两个积分之和。 ■

这就把简单函数的有限加权和规律传到了任意非负可测函数。对任意可测非负函数列 u_k ，再把线性用于有限部分和并用单调收敛，还得到 $\int \sum_{k \geq 1} u_k = \sum_{k \geq 1} \int u_k$ ，允许两边为无穷。例如 $(0, \infty)$ 上的 $\mathbb{1}_{(0,n)} \uparrow 1$ ，积分从 n 增至无穷；单调收敛并不承诺最终总量有限。

3.4.2.3 有符号积分与可积性

非负函数只累积贡献，允许总量为 $+\infty$ 。含正负值的函数却可能一边累积 $+\infty$ 、另一边累积 $-\infty$ ，不能用二者相消来定义一个数。因此先把正、负贡献分别计算，再决定它们是否允许相减。

定义 3.38 有符号积分与可积性 在测度空间 $(X, \mathcal{A}, \mu)$ 上，对可测实函数 f ，令

$$f^+(x) = \max\{f(x), 0\}, \quad f^-(x) = \max\{-f(x), 0\}.$$

若 $\int_X f^+ d\mu$ 与 $\int_X f^- d\mu$ 不同时为无穷，则定义

$$\int_X f d\mu = \int_X f^+ d\mu - \int_X f^- d\mu.$$

若

$$\int_X |f| d\mu < \infty, \quad (3.35)$$

就称 f 绝对可积 (absolutely integrable) 或 Lebesgue 可积。

由于 $f = f^+ - f^-$ 且 $|f| = f^+ + f^-$ ，可积性等价于正负两部分的积分都有限。此时积分没有“无穷减无穷”的歧义，并满足

$$\left| \int_X f d\mu \right| \leq \int_X |f| d\mu.$$

有符号线性也需要这项有限性。若 f, g 可积, $|f+g| \leq |f|+|g|$ 先保证 $f+g$ 可积。记 $u = f+g$, 由逐点恒等式 $u^+ + f^- + g^- = u^- + f^+ + g^+$, 对两边的非负项积分并使用已证明的线性, 再移去有限项, 得到 $\int(f+g) = \int f + \int g$ 。非负常数倍由前面的引理处理, 负常数倍则交换正负部分, 所以 $\int(\alpha f + \beta g) = \alpha \int f + \beta \int g$ 对任意实数 α, β 成立。若 $f \leq g$ 几乎处处, 对非负函数 $g-f$ 积分还得到 $\int f \leq \int g$ 。

在闭区间上有界且 Riemann 可积的函数也 Lebesgue 可积, 两种积分取值相同。Lebesgue 积分保留这些函数的熟悉面积值, 还可以处理更广的一类可测函数。两个可测且几乎处处相等的函数具有相同积分。例如在 Lebesgue 测度下, 修改可测函数在单点上的值仍得到可测函数, 也不改变积分。反过来, 积分有限不表示函数处处有界, 也不自动给出连续性。例如在 $(0, 1)$ 上, $x^{-1/2}$ 无界却可积: 对 $x^{-1/2} \mathbb{1}_{[1/n, 1]}$ 用闭区间上的熟悉积分, 再用单调收敛, 得到 $\int_0^1 x^{-1/2} dx = \lim_n 2(1 - n^{-1/2}) = 2$ 。而对 x^{-1} 同样计算得到 $\lim_n \log n = +\infty$; 它的非负积分有定义, 却不是可积函数。若在 $(-1, 1)$ 取 $f(x) = 1/x$ (原点取 0), 正负部分积分都为无穷, Lebesgue 积分便没有定义。对称截断得到的零是另一种极限约定, 不能替代这里的积分。

有限集合上的积分就是带测度权重的求和。回到第 3.1 节的 $X = \{a, b\}$, $\mu(\{a\}) = 1$ 、 $\mu(\{b\}) = 2$, 并令 $f(a) = 3$ 、 $f(b) = -1$ 。则

$$\int_X f d\mu = 3 \times 1 + (-1) \times 2 = 1, \quad \int_X |f| d\mu = 5.$$

积分是总量; 若要把它称为平均, 还要除以总质量 $\mu(X) = 3$, 得到 $1/3$ 。概率测度的总质量为 1, 才无需这一步归一化。这个小例子也显示, 正负部分可以相消, 可积性却要分别控制它们的大小。一般地, 按 μ 取一个有限平均要求 f 可积且 $0 < \mu(X) < \infty$, 此时平均为 $\mu(X)^{-1} \int_X f d\mu$ 。总质量为零时不能相除, 总质量无穷时也不能把有限积分除以无穷来定义这项平均; 需要另行指定局部区域或归一化方式。

3.4.3 乘积积分与次序交换

前面讨论的是一个位置 x 上的贡献; 若函数同时依赖 x 和 y , 就要给成对位置 (x, y) 所在的集合赋权重。对两组分别给定的权重, 最自然的扩展是让矩形 $A \times B$ 的权重等于两边权重的乘积。它是面积“长乘宽”以及有限双重加权重的共同推广, 称为乘积测度。

为了由矩形权重唯一确定一般集合的权重, 下面采用一种常见条件: 整个空间可以由可数个有限权重的区域覆盖。这比要求空间的总权重有限宽松, 例如整个实数轴长度无限, 却能写成区间 $[-n, n]$ 的并。

定义 3.39 σ 有限测度 若存在 $E_n \in \mathcal{A}$, 使 $X = \bigcup_{n=1}^{\infty} E_n$ 且对每个 n 有 $\mu(E_n) < \infty$, 称测度空间 $(X, \mathcal{A}, \mu)$ 是 σ 有限 (sigma-finite) 的。

例如 $\mathbb{N}$ 上的计数测度可由有限集合 $\{0, \dots, n\}$ 覆盖, 因而 σ 有限; 不可数集合上的计数测度则不满足这一条件, 因为可数个有限集合的并仍然可数。所以“每个点质量有限”远弱于“整个空间能由可数个有限质量区域覆盖”。

在两个 σ 有限测度空间上, 乘积测度定理保证: 矩形上的乘积权重能扩展为一个存在且唯一的测度。下面用这一性质刻画它。

定义 3.40 乘积 σ 代数与乘积测度 给定两个 σ 有限测度空间 $(X, \mathcal{A}, \mu)$ 与 $(Y, \mathcal{B}, \nu)$ 。包含所有矩形 $A \times B$ ($A \in \mathcal{A}, B \in \mathcal{B}$) 的最小 σ 代数称为乘积 σ 代数, 记为 $\mathcal{A} \otimes \mathcal{B}$ 。在该 σ 代数上, 对任意这样的 A, B 满足

$$(\mu \otimes \nu)(A \times B) = \mu(A)\nu(B)$$

的测度记为 $\mu \otimes \nu$, 称为乘积测度 (product measure)。这里仍约定 $0 \cdot \infty = 0$ 。

对矩形上的指示函数, 先对 x 积分或先对 y 积分都得到同一个乘积。一般函数能否继续交换积分次序, 则取决于非负性或绝对可积性, 下面给出准确条件。若脱离 σ 有限框架, 乘积测度的唯一性和相应积分结论需要更谨慎的版本。

有限网格把这个构造还原为双重求和。若 $X = \{x_1, \dots, x_m\}$ 、 $Y = \{y_1, \dots, y_n\}$ 分别带权重 u_i, v_j , 则

$$\int_{X \times Y} f d(\mu \otimes \nu) = \sum_{i=1}^m \sum_{j=1}^n f(x_i, y_j) u_i v_j.$$

有限和可以直接交换次序; 一般测度空间中的累次积分还要处理无穷值与极限, 不能只由矩形公式推出。还要注意, 乘积测度是一种特定构造; 一般的二元概率分布可以包含两个变量之间的依赖, 并不必然等于两边概率测度的乘积。第 10 章会在联合分布与独立性的语境中回用这一区别。

乘积测度确定成对位置的权重, 尚未保证任意函数都能按两个次序分别累计。这里比较累次积分与乘积空间上的积分: 非负性允许逐步累计, 绝对可积性排除正负无穷相消; 刚建立的单调收敛把简单函数的累计规则推广到一般非负函数。

定理 3.41 Tonelli 与 Fubini 定理 设 $(X, \mathcal{A}, \mu)$ 与 $(Y, \mathcal{B}, \nu)$ 为 σ 有限测度空间, 且 $f : X \times Y \rightarrow \overline{\mathbb{R}}$ 对乘积 σ 代数可测。

- 若 $f \geq 0$, 则每个截面 $y \mapsto f(x, y)$ 与 $x \mapsto f(x, y)$ 都可测, 并且两个内层积分函数

$$x \mapsto \int_Y f(x, y) d\nu(y), \quad y \mapsto \int_X f(x, y) d\mu(x)$$

分别关于 x 与 y 可测, 且

$$\begin{aligned} \int_{X \times Y} f d(\mu \otimes \nu) &= \int_X \left(\int_Y f(x, y) d\nu(y) \right) d\mu(x) \\ &= \int_Y \left(\int_X f(x, y) d\mu(x) \right) d\nu(y). \end{aligned}$$

允许共同值为 $+\infty$ 。这是 Tonelli 定理。

- 若 $\int_{X \times Y} |f| d(\mu \otimes \nu) < \infty$, 则 $y \mapsto f(x, y)$ 对几乎每个 x 可积, $x \mapsto f(x, y)$ 对几乎每个 y 可积。把相应内层积分函数在例外集上置为 0 后, 它们分别可积, 上述等式对 f 成立并取有限值。这是 Fubini 定理。

证明可分为集合与函数两层。对矩形指示函数 $\mathbb{I}_{A \times B}$, 三种积分都等于 $\mu(A)\nu(B)$; 有限可加性把这个结论扩展到有限分割形成的集合。从这些集合进入乘积 σ 代数中的任意可测集合, 还需要测度论的扩张论证, 不是仅靠每个矩形上的等式便能完成; 完整论证见所引测度论教材⁴。本章关注扩张之后的函数层: 指示函数的结论经线性组合进入非负简单函数, 再经 $s_n \uparrow f$ 和单调收敛进入任意非负可测函数, 得到 Tonelli。若 f 绝对可积, 则对 f^+ 和 f^- 分别应用 Tonelli; 绝对积分有限保证两部分不会出现无穷减无穷, 相减才得到 Fubini。因此, 矩形上的核对只是证明的起点; 一般集合的测度扩张与函数的单调逼近都不可省略。

这里非负性允许无穷值, 绝对可积性则排除了依赖积分次序的条件相消。例如在 $\mathbb{N} \times \mathbb{N}$ 上使用计数测度时, Tonelli 说明非负双重级数可以任意交换求和次序; Fubini 说明绝对收敛的双重级数也可以这样做。若既不非负也不绝对可积, 交换次序可能改变结果, 甚至一个次序收敛而另一个发散。因此, 交换两个积分或求和之前, 需要检查函数非负, 或者绝对积分有限; 仅确认每个内层计算有值还不够。

⁴G. B. Folland, *Real Analysis: Modern Techniques and Their Applications*, Wiley, 1999, 2nd ed.

示例 3.42 行列各自可加仍不足以换序 以正整数 $i, j = 1, 2, \dots$ 作为行列索引, 令 $a_{i,j} = \mathbb{I}\{j = i\} - \mathbb{I}\{j = i + 1\}$, 两边均用计数测度。每一行只有一个 1 和一个 -1, 故 $\sum_j a_{i,j} = 0$; 第一列的和为 1, 其余每一列的和为 0。于是

$$\sum_{i=1}^{\infty} \left(\sum_{j=1}^{\infty} a_{i,j} \right) = 0, \quad \sum_{j=1}^{\infty} \left(\sum_{i=1}^{\infty} a_{i,j} \right) = 1.$$

两种累次和都有有限值, 却不相等。每行的绝对值和为 2, 所以整个绝对积分为无穷, 正负部分也各为无穷。失效的是 Fubini 的绝对可积条件, 而非某一行的计算规则。

σ 有限也有实际作用。在 $[0, 1]$ 上让 x 采用 Lebesgue 测度、 y 采用不可数集合上的计数测度, 取非负函数 $f(x, y) = \mathbb{I}\{x = y\}$ 。对角线属于乘积 σ 代数, 但先对 y 计数再对 x 积分得到 1, 先对 x 求长度再对 y 计数却得到 0。这里不满足本章 Tonelli 版本的 σ 有限条件, 不能只凭非负性换序。

3.4.4 积分换元与坐标变换

积分的定义、权重和可积条件已经确定, 现在可以利用函数或区域的结构计算它。换元重新表示同一个区域, 函数值要随坐标复合, 每块区域的体积权重也要随之修正。链式法则中的 Jacobian 把一个输入扰动映成输出扰动; 这里则需要把多个方向共同张成的体积缩放成一个非负权重, 起作用的是 Jacobian 行列式的绝对值。

一维换元中, $u = T(x)$ 把长度 dx 缩放为约 $|T'(x)|dx$ 。在 d 维, 局部线性近似

$$T(\mathbf{x} + \mathbf{h}) \approx T(\mathbf{x}) + \mathbf{J}_T(\mathbf{x})\mathbf{h}$$

把一个小平行多面体的有向体积乘以 $\det \mathbf{J}_T(\mathbf{x})$, 普通体积则乘以其绝对值。行列式为零意味着这个局部线性映射把至少一个非零方向压为零。此时 Jacobian 不可逆, 不能用它构造可微的局部逆映射; 原函数是否还有其他形式的逆, 需另外判断。

设 $U, V \subseteq \mathbb{R}^d$ 为开集, $T : U \rightarrow V$ 是连续可微双射, 逆映射也连续可微, 并且 $\det \mathbf{J}_T(\mathbf{x}) \neq 0$ 。对非负可测函数或绝对可积函数 g , 多维换元公式为

$$\int_V g(\mathbf{y}) d\mathbf{y} = \int_U g(T(\mathbf{x})) |\det \mathbf{J}_T(\mathbf{x})| d\mathbf{x}. \quad (3.36)$$

绝对值不可省略, 因为积分中的体积不随坐标方向翻转而变成负数。一维单调换元是 $d = 1$ 的特例; 若在定积分中保留有向上下限, 也可让导数符号由上下限次序吸收。公式的证明可理解为把 U 分成足够小的区域: 在每

一块上用 $T(\mathbf{x} + \mathbf{h}) \approx T(\mathbf{x}) + \mathbf{J}_T(\mathbf{x})\mathbf{h}$ 替代原映射，线性映射把该块体积乘以 $|\det \mathbf{J}_T(\mathbf{x})|$ ，再让分割尺度趋于零。这条路线只提供直观框架；严格证明还要控制局部近似误差、像集重叠和可测逼近，不能把逐点线性化直接当作全局换元等式。

示例 3.43 极坐标中的面积权重 令 $D = \{\mathbf{x} \in \mathbb{R}^2 : \|\mathbf{x}\|_2 \leq 1\}$ ，并令 $T(r, \theta) = (r \cos \theta, r \sin \theta)$ 。在开集 $(0, 1) \times (0, 2\pi)$ 上， T 是到开圆盘内部去掉原点和正 x 轴径向接缝后的区域的连续可微双射，逆映射也连续可微。其 Jacobian 矩阵的行列式为

$$\det \begin{bmatrix} \cos \theta & -r \sin \theta \\ \sin \theta & r \cos \theta \end{bmatrix} = r.$$

圆周、原点和径向接缝都是二维零测集；参数矩形的边界也是零测集。因此在上述开集上应用换元公式，再补回这些零测部分，便得到

$$\int_D 1 \, d\mathbf{x} = \int_0^{2\pi} \int_0^1 r \, dr \, d\theta = \pi.$$

这里积分上下限包含端点不改变积分值。若参数化在正测度区域上重复覆盖，则不能直接使用上述双射版本，否则同一点会被重复计数。

3.4.5 微分与积分的关系

换元改变坐标表示，以下公式则把局部变化的累计与端点或边界联系起来。一维乘积求导产生分部积分，沿曲线的链式求导产生端点差，区域中的流出率则对应边界通量。三种关系采用不同的积分对象，不能省去各自的端点、方向或面积权重。

3.4.5.1 分部积分与积分余项

先回顾微积分基本定理的连续版本。若 g 在 $[a, b]$ 上连续， $H(x) = \int_a^x g(t) \, dt$ 在内点处满足 $H'(x) = g(x)$ ；若 $H \in C^1([a, b])$ ，则 $\int_a^b H'(x) \, dx = H(b) - H(a)$ 。这里 C^1 表示一阶连续可微，在闭区间端点采用单侧导数的连续延拓。第一条可由 $[H(x+h) - H(x)]/h - g(x) = h^{-1} \int_x^{x+h} (g(t) - g(x)) \, dt$ 和连续性得到；第二条再对 $H(x) - H(a) - \int_a^x H'(t) \, dt$ 使用零导数蕴含常值的中值定理。这说明所用的是连续导数的积分，不是“几乎处处存在导数便能恢复函数”的无条件结论。

有些乘积的积分难算, 但把导数转移到另一个因子后会简化。分部积分就是这种转移规则, 代价是增加边界贡献。若 $u, v \in C^1([a, b])$, 由乘积求导 $(uv)' = u'v + uv'$ 并在 $[a, b]$ 上积分, 可得

$$\int_a^b u(x)v'(x) dx = [u(x)v(x)]_a^b - \int_a^b u'(x)v(x) dx. \quad (3.37)$$

例如, 取 $u(x) = x$ 、 $v'(x) = e^x$, 得到 $\int_0^1 xe^x dx = [xe^x]_0^1 - \int_0^1 e^x dx = 1$ 。在这个区间公式中, 边界项是 $u(b)v(b) - u(a)v(a)$, 省略前须证明这两个端点乘积相等。对无穷区间使用相应公式时, 还需证明截断边界的贡献有所需极限, 例如由充分衰减使其趋于零。

分部积分还能把第 3.3.4 节的局部二阶变化累计成有限位移的余项。设连接 $\mathbf{x}$ 与 $\mathbf{x} + \mathbf{h}$ 的线段包含在一个开集内, 且 f 在该开集上二阶连续可微。令 $\phi(t) = f(\mathbf{x} + t\mathbf{h})$, 对 $(1-t)\phi''(t)$ 在 $[0, 1]$ 上分部积分, 得到

$$\int_0^1 (1-t)\phi''(t) dt = -\phi'(0) + \phi(1) - \phi(0).$$

用链式法则代回, 便得到不挑选中间点的 Taylor 积分余项:

$$f(\mathbf{x} + \mathbf{h}) = f(\mathbf{x}) + \nabla f(\mathbf{x})^\top \mathbf{h} + \int_0^1 (1-t)\mathbf{h}^\top \nabla^2 f(\mathbf{x} + t\mathbf{h})\mathbf{h} dt.$$

权重 $1-t$ 说明越靠近位移起点的曲率贡献被累计得越多; 该表达式与前面的中间点余项描述同一有限变化, 但保留了整条线段上的曲率信息。

一般阶数也由同一操作得到。设 f 在连接 x_0 和 $x_0 + h$ 的线段邻域内 $r+1$ 阶连续可微, $r \geq 0$, 令 $\phi(t) = f(x_0 + th)$ 。记

$$I_r = \frac{1}{r!} \int_0^1 (1-t)^r \phi^{(r+1)}(t) dt.$$

基本定理给出 $I_0 = \phi(1) - \phi(0)$; 对 $r \geq 1$ 分部积分,

$$I_r = -\frac{\phi^{(r)}(0)}{r!} + \frac{1}{(r-1)!} \int_0^1 (1-t)^{r-1} \phi^{(r)}(t) dt = -\frac{\phi^{(r)}(0)}{r!} + I_{r-1}.$$

逐次代入并用 $\phi^{(k)}(0) = h^k f^{(k)}(x_0)$, 便得

$$f(x_0 + h) = \sum_{k=0}^r \frac{f^{(k)}(x_0)}{k!} h^k + \frac{h^{r+1}}{r!} \int_0^1 (1-t)^r f^{(r+1)}(x_0 + th) dt. \quad (3.38)$$

参数化 $x_0 + th$ 同时处理正、负 h 。若 $|f^{(r+1)}| \leq M$, 积分权重的总量为 $1/(r+1)$, 故余项不超过 $M|h|^{r+1}/(r+1)!$, 与前面的中间点余项界一致。例如立方函数在 $r=2$ 时有 $f''' = 6$, 余项就是 $(h^3/2) \int_0^1 6(1-t)^2 dt = h^3$ 。

多元函数沿 $\phi(t) = f(\mathbf{x} + t\mathbf{h})$ 使用同一公式； $r = 1$ 便还原前述 Hessian 积分余项。

3.4.5.2 路径积分与端点关系

换元仍是在同维区域内计算体积积分；如果贡献只沿一条路径累积，就应改用弧长或带方向的路径增量，不能继续套用全空间体积权重。设分段连续可微路径 $\gamma : [a, b] \rightarrow \mathbb{R}^d$ 。对沿路径连续的标量函数 $h : \mathbb{R}^d \rightarrow \mathbb{R}$ ，标量线积分定义为

$$\int_{\gamma} h \, ds = \int_a^b h(\gamma(t)) \|\gamma'(t)\|_2 \, dt.$$

速度的范数把参数增量换成弧长，因此反转路径方向不改变该积分。对沿路径连续的向量场 $\mathbf{F} : \mathbb{R}^d \rightarrow \mathbb{R}^d$ ，向量场线积分则定义为

$$\int_{\gamma} \mathbf{F} \cdot d\mathbf{r} = \int_a^b \mathbf{F}(\gamma(t))^{\top} \gamma'(t) \, dt.$$

若 $\mathbf{F} = \nabla\phi$ 且 ϕ 连续可微，链式法则给出

$$\int_{\gamma} \nabla\phi \cdot d\mathbf{r} = \phi(\gamma(b)) - \phi(\gamma(a)). \quad (3.39)$$

因此梯度场的路径积分只依赖端点。向量场线积分在路径方向反转时变号；若漏掉参数化导数 $\gamma'(t)$ ，就会丢失方向和行进速度的信息。

示例 3.44 同一路径上的长度、端点差与环流 取单位圆的上半圆路径 $\gamma(t) = (\cos t, \sin t)$, $0 \leq t \leq \pi$ 。它的速度范数恒为 1，所以 $\int_{\gamma} 1 \, ds = \pi$ 。取 $\phi(x, y) = x$ ，则 $\nabla\phi = (1, 0)^{\top}$ ，

$$\int_{\gamma} \nabla\phi \cdot d\mathbf{r} = \int_0^{\pi} -\sin t \, dt = -2 = \phi(-1, 0) - \phi(1, 0).$$

换成旋转场 $\mathbf{F}(x, y) = (-y, x)^{\top}$ 时， $\mathbf{F}(\gamma(t))^{\top} \gamma'(t) = 1$ ，沿上半圆的积分为 π 。但沿同样端点的直径路径 $\eta(t) = (1 - 2t, 0)$, $0 \leq t \leq 1$ ，内积恒为零，积分为 0。向量场连续甚至光滑，也不能单独保证路径无关。沿完整单位圆逆时针一周，这个旋转场的积分为 2π ；梯度场沿闭合路径的端点差必须为零，所以它不可能在整个平面上写成一个连续可微势函数的梯度。

3.4.5.3 散度积分与边界通量

路径积分沿行进方向累计，通量则计算穿过边界的贡献。在向量场 $\mathbf{F} = (F_1, \dots, F_d)^{\top}$ 中，散度定义为 $\nabla \cdot \mathbf{F} = \sum_{i=1}^d \partial F_i / \partial x_i$ ；它把各坐标方向的局

部流出率相加。相邻小区域的公共边界法向相反，内部交换在总和中相消，剩下的应是外边界的净流出。

以下采用经典的规则区域版本： Ω 是有界开区域，其边界由有限个 C^1 曲面片组成，每个光滑片附近区域位于边界的一侧，片间接缝的边界面积为零。光滑区域、多边形和通常的多面体均符合这一条件。若向量场 $\mathbf{F}$ 在 $\overline{\Omega}$ 的一个开邻域内连续可微，散度定理（divergence theorem）写成

$$\int_{\Omega} \nabla \cdot \mathbf{F} \, d\mathbf{x} = \int_{\partial\Omega} \mathbf{F}^T \mathbf{n} \, dS, \quad (3.40)$$

其中 $\mathbf{n}$ 是外单位法向量， dS 表示边界上的面积元素。这个公式把区域内部与区域边界两种积分联系起来；左边汇总区域内部的局部流出率，右边计算穿过边界的净通量。它的严格适用条件随区域与函数空间版本而异；边界不符合上述分片条件、区域无界或采用弱导数时，需要使用相应推广并重新核对边界项。分部积分、路径积分与散度定理共同说明，局部导数进入整体积分时，通常会留下不可忽略的边界信息。

例如单位圆盘 Ω 上的 $\mathbf{F}(x, y) = (x, y)^T$ 有散度 2，故左边为 2π 。边界参数化 $\gamma(t) = (\cos t, \sin t)$ ， $0 \leq t \leq 2\pi$ ，外单位法向就是 $\mathbf{n} = \gamma(t)$ ，弧长元素为 $dS = dt$ ；因此 $\mathbf{F}^T \mathbf{n} = 1$ ，右边也为 2π 。改用内法向会得到 -2π ，这不是同一定理中的方向约定。前例的旋转场散度为零，且在圆周上始终与法向垂直，所以通量为零，尽管沿切向的环流为 2π 。这一区别说明线积分和通量计算的不是同一种贡献。

3.5 函数列的收敛与性质保持

现在让被研究的函数本身随索引变化。 $f_n : X \rightarrow \mathbb{R}$ 仍是一个序列，只是每一项是函数；固定 x 以后， $f_n(x)$ 才成为第 3.2 节的数值序列。比较整个函数还要选择误差尺度，并判断极限是否保留连续性、变化率或积分。这些任务所需的基础不同：逐点收敛只需要数值极限，一致误差使用上确界，几乎处处回用零测集，积分误差回用积分，导数逼近则回用第 3.3 节建立的局部变化信息。

3.5.1 收敛方式与极限存在

3.5.1.1 逐点收敛与一致收敛

固定一个输入以后，比较的只是一列实数。这里不需要函数可微或可积，甚至不需要在输入集合上指定距离；函数值仍按实数绝对值比较。

定义 3.45 逐点收敛 设 $f_n, f : X \rightarrow \mathbb{R}$ 。若

$$\forall x \in X, \quad \forall \varepsilon > 0, \quad \exists N = N(x, \varepsilon) \in \mathbb{N},$$

$$\forall n \geq N, \quad |f_n(x) - f(x)| < \varepsilon,$$

即对每个 x 都有 $\lim_n f_n(x) = f(x)$, 称 f_n 逐点收敛到 f 。

定义中的每个位置都只比较一列实数；整体误差却不能靠分别检查各位置来控制。即使每个输入处的误差最终都很小，开始稳定的时刻仍可能依赖输入。若希望一次选定迭代次数后就控制全部输入，需要更强的一致条件。

定义 3.46 函数列的一致收敛 设 X 为非空集合， $f_n, f : X \rightarrow \mathbb{R}$ 。若

$$\forall \varepsilon > 0, \quad \exists N = N(\varepsilon) \in \mathbb{N}, \quad \forall x \in X, \quad \forall n \geq N, \quad |f_n(x) - f(x)| < \varepsilon,$$

就称 f_n 在 X 上一致收敛到 f 。等价地，

$$\|f_n - f\|_\infty := \sup_{x \in X} |f_n(x) - f(x)| \longrightarrow 0. \quad (3.41)$$

这里的上确界检查全部输入，没有忽略零测集。

两条定义的区别落在量词次序。逐点收敛允许 N 依赖 x ；一致收敛把 $\exists N$ 移到 $\forall x$ 之前，同一个 N 必须同时控制全部输入。区别不在“趋近”这个词，而在误差阈值之后允许谁依赖谁。下面用同一列函数比较这两种控制。

在 $[0, 1]$ 上取 $f_n(x) = x^n$ 。它逐点收敛到

$$f(x) = \begin{cases} 0, & 0 \leq x < 1, \\ 1, & x = 1. \end{cases}$$

每个固定的 $0 < x < 1$ 都有 $x^n \rightarrow 0$ ，而端点 1 的值始终为 1。但对每个 n , $\sup_{0 \leq x < 1} x^n = 1$ ，所以收敛不一致。从量词看，固定 $\varepsilon = 1/2$ 后，无论选多大的 N ，在 $n = N$ 时总能选 $x_N = (3/4)^{1/N} < 1$ ，使误差 $x_N^N = 3/4 > \varepsilon$ 。失败的位置可以随 n 移动；不能把“每个位置最终变小”改写成“某一轮以后所有位置都小”。若把范围缩为 $[0, a]$ ，其中 $a < 1$ ，则上确界误差为 $a^n \rightarrow 0$ ，同一公式又变成一致收敛。

3.5.1.2 几乎处处收敛与积分误差

如果某些输入占零权重，是否必须在它们上面也逼近？积分任务通常不需要，但必须先固定采用的测度和可忽略的范围。

定义 3.47 几乎处处收敛 给定测度空间 $(X, \mathcal{A}, \mu)$ 和实函数 f_n, f ，若存在 $E \in \mathcal{A}$ 、 $\mu(E) = 0$ ，使

$$\forall x \in X \setminus E, \quad \forall \varepsilon > 0, \quad \exists N = N(x, \varepsilon), \quad \forall n \geq N, \quad |f_n(x) - f(x)| < \varepsilon,$$

就称 f_n 在 μ 下几乎处处收敛到 f 。

这里是先选一个零测集，再在它的补集上逐点收敛；每个精度和每一项不能任意丢掉不同的正测度区域。可数个零测例外可以取并后统一，任意不可数个零测集的并却未必零测。例如 x^n 关于 $[0, 1]$ 上的 Lebesgue 测度几乎处处趋于零，虽然它不在 $x = 1$ 处趋于零。又如 $f_n(x) = n \mathbb{I}_{\{0\}}(x)$ 几乎处处趋于零，但在 0 处连有限极限都没有。若要求极限仍可测，本章采用各 f_n, f 均可测的版本；在未完备空间中，不能从几乎处处关系自动推出任意指定的例外点取值可测。

如果关心的是按测度累计的误差，就要先说明被比较的函数属于什么空间。积分不区分只在零测集上不同的可测函数：即使 f 不处处为零， $\int |f|^p d\mu$ 也可能为零。把这类函数视为同一个元素，才能让零误差对应空间中的同一个对象。

定义 3.48 L^p 空间与范数 设 $(X, \mathcal{A}, \mu)$ 为测度空间， $1 \leq p < \infty$ 。对可测实函数定义等价关系

$$f \sim g \iff f = g \text{ 在 } \mu \text{ 下几乎处处成立.}$$

$L^p(\mu)$ 由满足 $\int_X |f|^p d\mu < \infty$ 的可测实函数的等价类 $[f]$ 组成，其范数定义为

$$\|[f]\|_{L^p(\mu)} = \left(\int_X |f|^p d\mu \right)^{1/p}.$$

该值不依赖代表元的选择。下文用代表元 f 代写等价类 $[f]$ ，并简记范数为 $\|f\|_p$ 。

固定这个空间以后，可以把函数之差放入同一积分表达式来计算误差。 $p = 1$ 累计绝对误差， $p = 2$ 累计平方误差后再开平方；它们强调的误差大小不同，但都按同一个测度汇总整个定义域。

定义 3.49 L^p 收敛 设 $1 \leq p < \infty$, 且 $f_n, f \in L^p(\mu)$. 若

$$\|f_n - f\|_p := \left(\int_X |f_n - f|^p d\mu \right)^{1/p} \longrightarrow 0, \quad 1 \leq p < \infty. \quad (3.42)$$

就称 f_n 在 $L^p(\mu)$ 中收敛到 f 。

展开量词就是：对每个 $\varepsilon > 0$ 存在 N , 使所有 $n \geq N$ 的积分误差范数小于 ε 。这里受控的是整个积分，不是对每个 x 分别要求 $|f_n(x) - f(x)| < \varepsilon$ 。

回到上面的 $f_n(x) = x^n$ 及其逐点极限 f , 对任意有限 $p \geq 1$,

$$\|f_n - f\|_p^p = \int_0^1 x^{np} dx = \frac{1}{np+1} \longrightarrow 0.$$

同一函数列因此逐点且在每个有限 L^p 意义下收敛，却不一致收敛。区别来自最坏输入与累计误差采用了不同尺度。图 3.7 把接近 $x = 1$ 的区域与误差数值并列。每个固定的 $x < 1$ 最终都会下降，但每一轮总有更靠近 1 的新位置保留接近 1 的误差。




图 3.7 x^n 在 $[0, 1]$ 上的两种整体尺度。左图蓝、红、黄线分别取 $n = 2, 8, 32$; 灰线与端点标记表示逐点极限，它在 $x < 1$ 处为零、在 $x = 1$ 处为 1。右图黄色曲线为精确的 L^2 误差 $(2n+1)^{-1/2}$, 灰虚线为始终等于 1 的普通上确界误差；单点 $x = 1$ 的修改不影响积分。图解析教学示例。

若 $\mu(X) < \infty$ 且 $f_n, f \in L^p$, 一致收敛蕴含 L^p 收敛, 因为

$$\|f_n - f\|_p \leq \mu(X)^{1/p} \|f_n - f\|_\infty.$$

当空间测度无穷时, 即使各项仍属于 L^p , 这个推论也可能失败。在 $\mathbb{R}$ 上采用 Lebesgue 测度, 固定 $1 \leq p < \infty$, 并取

$$f_n(x) = \frac{1}{n} \mathbb{I}_{[0, n^p]}(x).$$

每个 f_n 都属于 L^p , 且 $\sup_x |f_n(x)| = 1/n \rightarrow 0$, 所以一致收敛到零; 但

$$\|f_n\|_p^p = \frac{n^p}{n^p} = 1,$$

因而不在于 L^p 中收敛到零。幅度虽降低, 非零区域却同步扩大, 累计误差没有随之减小。

反过来, 积分误差小也不保证整列在几乎每个点收敛。

示例 3.50 小区间轮流扫过定义域 在 $[0, 1)$ 上按轮次细分区间, 令

$$f_{2^k+j}(x) = \mathbb{I}_{[j2^{-k}, (j+1)2^{-k})}(x), \quad k = 0, 1, \dots, \quad j = 0, \dots, 2^k - 1.$$

第 k 轮依次访问 2^k 个小区间, 每个函数的 L^p 范数为 $2^{-k/p}$, 所以对每个有限 $p \geq 1$, $f_n \rightarrow 0$ 在 L^p 中成立。但每个 $x \in [0, 1)$ 在每轮恰有一次取值 1, 也在无穷多个其他时刻取值 0。因此整列在每个 x 处都不收敛。积分看到每次被访问的区间越来越小, 逐点收敛却要求同一个输入从某一时刻起一直稳定, 这两个要求不能互代。

普通上确界会被单个异常点改变, 而保持可测性的零测集修改不影响积分。若仍要控制最坏误差, 却允许忽略测度为零的例外, 就比较函数绝对值的本质上界。

定义 3.51 本质有界与绝对值的本质上界 设 $(X, \mathcal{A}, \mu)$ 为测度空间, $f : X \rightarrow \mathbb{R}$ 可测。其绝对值 $|f|$ 的本质上确界 (essential supremum) 定义为

$$\operatorname{ess\,sup}_{x \in X} |f(x)| = \inf\{M \geq 0 : |f(x)| \leq M \text{ 几乎处处}\}.$$

若集合中没有有限的 M , 上式取 $+\infty$; 若上式有限, 就称 f 本质有界。这里衡量的是 $|f|$ 的大小, 不是一般有符号函数 f 的本质上确界。

定义 3.52 L^∞ 空间与范数 在同一测度空间上, $L^\infty(\mu)$ 由本质有界可测实函数的几乎处处等价类组成, 其范数定义为

$$\|f\|_{L^\infty} = \operatorname{ess\,sup}_{x \in X} |f(x)|. \quad (3.43)$$

同样用 f 代写等价类 $[f]$; 该范数不依赖代表元。

例如在 $[0, 1]$ 上使用 Lebesgue 测度, 令 $f(0) = 100$ 、其余位置 $f(x) = 0$, 则普通上确界为 100, $|f|$ 的本质上确界却为 0。相应地, $\|f_n - f\|_{L^\infty} \rightarrow 0$ 称为 L^∞ 收敛。对每个 $\varepsilon > 0$, 它要求某个 N 之后的全部误差都在几乎处处意义下小于 ε 。可取精度 $1/k$, 把各 n, k 对应的可测零测例外并为一个零测集 E ; 于是存在同一个 E , 使 f_n 在 $X \setminus E$ 上一致收敛。反之, 这种补集上的一致收敛立即给出 L^∞ 收敛。因此它蕴含几乎处处收敛, 却不一定是原集合上的一致收敛。上面的 $n\mathbb{I}_{\{0\}}$ 在 L^∞ 中恒等于零, 普通上确界却为 n 。对 x^n , 本质上确界误差仍为 1, 因为接近 1 的一整段正测度区间保留大误差, 不是删除端点就能消除。

L^∞ 与有界函数上的普通上确界范数采用不同的对象: 普通上确界范数区分单点修改, L^∞ 范数忽略的是 μ 零测集上的修改。对 $1 \leq p < \infty$, 定义 3.48 中的积分表达式满足齐次性和三角不等式, 而几乎处处等价关系保证范数为零时, 空间中的元素就是零元素。这里“范数”指非负、绝对齐次、满足三角不等式且只在零元素上为零的长度函数; L^p 的三角不等式及完整空间理论留到第 5 章。当 $0 < p < 1$ 时, 同一积分表达式仍可用于来度量误差大小, 但通常不满足三角不等式, 所以不是范数; 本章不把这一区间记作范数空间。

一个固定函数序列的一致收敛, 讨论的是 n 增大时对所有输入能否共同控制。统计学习中“经验平均一致逼近总体平均”通常还要对候选函数类取上确界, 控制对象形如

$$\sup_{f \in \mathcal{F}} \left| \frac{1}{n} \sum_{i=1}^n f(X_i) - \int f \, dP \right|.$$

这里的一致性针对候选函数 $f \in \mathcal{F}$, 不是本节式 (3.41) 中针对输入 $x \in X$ 的一致收敛。两者都出现上确界, 却不能混为同一概念。其中 $X_1, \dots, X_n$ 是来自分布 P 的样本, $\mathcal{F}$ 是待比较的可积函数类。逐个 f 找到的样本量要求可以不同; 对 $\mathcal{F}$ 一致则要求一个共同的样本量控制整类函数。

几乎处处和 L^p 范数还依赖所选测度。设 P, Q 定义在同一个可测空间上。若 Q 对 P 绝对连续 (absolutely continuous), 记作 $Q \ll P$, 则原来 P 意义下的零测例外在 Q 下仍可忽略; 也就是对任意可测 A , $P(A) = 0$ 蕴含 $Q(A) = 0$ 。这一测度关系不等同于前面映射的连续性; 概率论中的正

式展开见定义 10.4。若没有 $Q \ll P$ ，换分布可能给原零测集正质量。例如 P 是 $[0, 1]$ 上的均匀分布， Q 把全部质量放在 0 点；两个只在 0 处不同的函数在 P 意义下等价，在 Q 意义下却可能具有完全不同的误差。即使 $Q \ll P$ ， L^p 收敛也不能仅凭零测关系转移。令 P 是 $(0, 1)$ 上的长度测度， $Q(A) = \int_A (2\sqrt{x})^{-1} dx$ ，其总质量为 1，并有 $Q \ll P$ 。固定有限 $p \geq 1$ ，取 $u_n = n^{1/(2p)} \mathbb{I}_{(0, 1/n)}$ ，则

$$\|u_n\|_{L^p(P)}^p = n^{-1/2} \rightarrow 0, \quad \|u_n\|_{L^p(Q)}^p = \sqrt{n} \int_0^{1/n} \frac{dx}{2\sqrt{x}} = 1.$$

Q 虽没有给 P 零测集新增质量，却更看重靠近 0 的区域。若另有统一常数 C 使 $Q(A) \leq CP(A)$ 对所有可测 A 成立，从简单函数经单调逼近可得 $\|u\|_{L^p(Q)} \leq C^{1/p} \|u\|_{L^p(P)}$ ，此时才有直接的积分误差转移保证。

3.5.1.3 一致柯西列与极限存在

前面都先给出候选极限，再判断误差；实际构造时可能只知道后面的函数彼此很近。令 S 为任意非空集合， $\mathcal{F}_b(S)$ 为所有有界实函数 $S \rightarrow \mathbb{R}$ 的集合，配备普通上确界范数

$$\|f\|_\infty = \sup_{x \in S} |f(x)|.$$

这里用 $\mathcal{F}_b(S)$ 表示有界函数集合，区别于 $\mathcal{B}(X)$ 表示的 Borel 集合族。所比较的是两个函数之间的距离 $\|f - g\|_\infty$ ，它检查每个输入而不忽略零测例外。一致柯西条件就是

$$\forall \varepsilon > 0, \quad \exists N, \quad \forall m, n \geq N, \quad \forall x \in S, \quad |f_m(x) - f_n(x)| < \varepsilon.$$

这个空间完备。事实上，若 (f_n) 满足上述条件，对每个固定 x ， $(f_n(x))$ 是实柯西列，故存在 $f(x) = \lim_n f_n(x)$ 。取一个 n_0 使 $\|f_n - f_{n_0}\|_\infty \leq 1$ 对所有充分大的 n 成立，再令 $n \rightarrow \infty$ ，得到 $|f(x)| \leq |f_{n_0}(x)| + 1$ ，所以 f 有界。对任意 $\varepsilon > 0$ ，选 N 使 $m, n \geq N$ 时 $\|f_m - f_n\|_\infty < \varepsilon/2$ 。固定 $n \geq N$ 并令 $m \rightarrow \infty$ ，对所有 x 都有 $|f(x) - f_n(x)| \leq \varepsilon/2$ ，于是 $\|f - f_n\|_\infty \leq \varepsilon/2 < \varepsilon$ 。这证明 f_n 在该空间中收敛到 f ，而不只是分别得到了各个点的极限。

空间 L^∞ 也完备，但其元素是几乎处处等价类，范数是式 (3.43)。上面的逐点证明不能原封不动搬过去，因为不同 n 的代表函数可能各自在不同零测集上修改；严格证明需要先统一这些例外集合。

3.5.2 连续性与一致收敛

前面的完备性说明一致柯西列有函数极限，还可以追问原函数的性质是否保留。若度量空间 X 上的实函数 f_n 连续，且 f_n 一致收敛到 f ，则 f 连续。

固定 $x \in X$ 与 $\varepsilon > 0$, 先选 n 使 $\|f - f_n\|_\infty < \varepsilon/3$, 再由这个 f_n 在 x 处连续, 选 $\delta > 0$ 控制 $|f_n(x') - f_n(x)| < \varepsilon/3$ 。于是 $d(x, x') < \delta$ 时,

$$|f(x') - f(x)| \leq |f(x') - f_n(x')| + |f_n(x') - f_n(x)| + |f_n(x) - f(x)| < \varepsilon.$$

一致误差同时控制两端, 连续性才被保留。仅逐点收敛没有这个共同控制; 上面的 x^n 例子中, 各项连续, 极限在 $x = 1$ 处却不连续。这里回用的是第 3.3 节的连续性, 并未使用积分。

一致收敛是这个结论的充分条件, 不是极限连续的必要条件。例如 x^n 在 $[0, 1)$ 上的逐点极限恒为零, 仍然连续, 但其上确界误差始终为 1。这不反驳上面的定理, 只说明有些不满足统一误差条件的函数列也恰好保留了连续性。

3.5.3 求导与极限交换

连续性保留并不意味着变化率也保留。下面的两个反例分别从尖点和振荡说明差别。用平滑函数

$$f_\varepsilon(x) = \sqrt{x^2 + \varepsilon^2}, \quad \varepsilon > 0$$

逼近 $|x|$ 。由

$$0 \leq f_\varepsilon(x) - |x| = \frac{\varepsilon^2}{\sqrt{x^2 + \varepsilon^2} + |x|} \leq \varepsilon,$$

可知 f_ε 在整个 $\mathbb{R}$ 上一致收敛到 $|x|$ 。其导数为

$$f'_\varepsilon(x) = \frac{x}{\sqrt{x^2 + \varepsilon^2}}.$$

对每个 $x \neq 0$, 导数收敛到 $\text{sign}(x)$; 在 $x = 0$ 处始终为 0, 而 $|x|$ 在那里没有导数。即使人为规定 $\text{sign}(0) = 0$, 导数收敛也不一致。例如取 $x_\varepsilon = \varepsilon^2 > 0$, 则

$$f'_\varepsilon(x_\varepsilon) = \frac{\varepsilon}{\sqrt{1 + \varepsilon^2}} \longrightarrow 0, \quad \text{sign}(x_\varepsilon) = 1.$$

因此两者之差的绝对值趋于 1, 不可能一致收敛。所以函数值的一致逼近不能推出导数的一致逼近。讨论光滑近似时, 必须明确控制的是函数值、导数还是积分误差。振荡还给出另一个不依赖不可微点的障碍。令 $f_n(x) = \sin(nx)/n$, $x \in [0, 2\pi]$, 则 $\|f_n\|_\infty \leq 1/n \rightarrow 0$, 但 $f'_n(x) = \cos(nx)$ 不一致趋于零, 甚至在 $x = 0$ 始终为 1。图 3.8 右侧显示了这种差别。若目标是近似导数, 必须直接控制导数误差或补充保证导数收敛的条件; 只增加函数值的精度并不能消除高频振荡。

若直接控制导数,则可以反过来保证函数与导数一起收敛;还需在一个位置固定函数值,以免遗漏任意的竖直平移。下面给出闭区间上的一个便于核对的版本。

定理 3.53 一致导数逼近与求导保持 设 $a < b$, $f_n \in C^1([a, b])$ 。若存在 $x_0 \in [a, b]$ 使 $f_n(x_0) \rightarrow c$, 且 f'_n 在 $[a, b]$ 上一致收敛到 g , 则 f_n 在 $[a, b]$ 上一致收敛到

$$f(x) = c + \int_{x_0}^x g(t) dt.$$

函数 f 连续, 并在 (a, b) 内可微, 满足 $f' = g$ 。

证明. 各 f'_n 连续, 前面的连续性保持结论说明其一致极限 g 连续。微积分基本定理给出 $f_n(x) = f_n(x_0) + \int_{x_0}^x f'_n(t) dt$, 因此

$$\sup_{x \in [a, b]} |f_n(x) - f(x)| \leq |f_n(x_0) - c| + (b - a) \|f'_n - g\|_\infty \rightarrow 0.$$

连续的 g 可积, 微积分基本定理又给出内点处 $f'(x) = g(x)$ 。 ■

定理回用微分与闭区间积分, 不需要支配收敛。若不控制 $f_n(x_0)$, $f_n(x) = n$ 的导数虽恒为零, 函数值却没有有限极限; 若不控制导数的统一误差, 前面的振荡例子则会阻断求导保持。

3.5.4 积分与极限交换

前面已经比较了逐点收敛与几乎处处收敛; 其具体条件见定义 3.45 和定义 3.47。现在要判断, 把各个位置的极限合成一个函数后, 它的积分是否等于各项积分的极限。取值于扩展实数的函数列也沿用这一表述; 其中趋于 $+\infty$ 或 $-\infty$, 分别表示函数值最终超过或低于任意给定的实数阈值。逐点收敛允许达到同样精度所需的序号随 x 改变; 几乎处处收敛还允许在同一个零测集上没有极限。这两种条件都没有直接控制积分的误差。下面的例子甚至处处收敛, 积分却始终不靠近极限函数的积分。

3.5.4.1 积分下界与 Fatou 引理

在 $(0, 1)$ 上令

$$f_n(x) = n \mathbb{I}_{(0, 1/n)}(x).$$

对每个固定 $x > 0$, 充分大的 n 满足 $x \geq 1/n$, 故 $f_n(x) \rightarrow 0$; 然而

$$\int_0^1 f_n(x) dx = 1$$

对所有 n 成立。因此 $\lim_n \int f_n \neq \int \lim_n f_n$ 。峰越来越窄，却同时越来越高，逐点观察不到被压缩区域中保留下来的总质量。要交换极限与积分，必须阻止这种质量逃逸或集中。




图 3.8 两种交换运算的障碍。左图的尖峰支撑不断收缩，但高度同步增长，每条曲线的积分仍为 1；开圆点标出不取的上端点，竖虚线仅提示跳跃。右图取 $n=20$ ， $\sin(nx)/n$ 的函数幅度很小，导数 $\cos(nx)$ 仍有单位幅度。两图均为按给定函数公式构造的教学示例。

定理 3.36 保证非负函数逐点递增时可以交换极限与积分，不要求可积统一上界，也允许无穷总量。若仍要求非负，却允许函数值下降或振荡，收缩峰的例子说明等式可能失败。下面的 Fatou 引理给出这时仍能保留的单向不等式。对不收敛的函数列，回用定义 3.11，在每个 x 处用下极限记录尾部信息。

引理 3.54 Fatou 引理 若 $f_n : X \rightarrow [0, \infty]$ 可测，则

$$\int_X \liminf_{n \rightarrow \infty} f_n \, d\mu \leq \liminf_{n \rightarrow \infty} \int_X f_n \, d\mu. \quad (3.44)$$

证明. 令 $g_n = \inf_{k \geq n} f_k$ 。则 g_n 可测， $0 \leq g_n \uparrow \liminf_k f_k$ 。由单调收敛定理，

$$\int \liminf_k f_k \, d\mu = \lim_{n \rightarrow \infty} \int g_n \, d\mu.$$

对每个 $k \geq n$ 都有 $g_n \leq f_k$ ，故

$$\int g_n \, d\mu \leq \inf_{k \geq n} \int f_k \, d\mu.$$

令 $n \rightarrow \infty$ 便得到式 (3.44)。 ■

Fatou 引理通常只给一个方向, 因为积分可能在极限中损失质量。对上述收缩峰 f_n , 左边为 0, 右边为 1, 不等式严格成立。非负条件也不能直接删除。若改取 $u_n = -n\mathbb{I}_{(0,1/n)}$, 则 $\liminf_n u_n = 0$ 处处成立, 而 $\int u_n = -1$; 原不等式会变成错误的 $0 \leq -1$ 。若另有共同的可积下界 h 使 $u_n \geq h$, 则可以对 $u_n - h \geq 0$ 应用 Fatou, 再移去有限的 $\int h$ 。可积下界是可用的推广条件, 不是无条件允许负值。

3.5.4.2 可积支配与积分交换

若函数会振荡或取负值, 单调收敛不适用, Fatou 的单向不等式又不足以交换极限。另一种控制方法是用同一个可积函数限制所有逼近的绝对值; 它不要求变化单调, 而是阻止越来越高的峰在越来越窄的区域里藏住质量。

定理 3.55 支配收敛定理 设 $f_n, f : X \rightarrow \mathbb{R}$ 可测, $f_n \rightarrow f$ 几乎处处, 并且存在非负可积函数 g 使 $|f_n| \leq g$ 几乎处处对所有 n 成立, 则 f 可积, 而且

$$\lim_{n \rightarrow \infty} \int_X f_n d\mu = \int_X f d\mu.$$

此外, $\int |f_n - f| d\mu \rightarrow 0$ 。

证明. 把收敛或控制条件失效的可测零测集的可数并记为 N , 并将 f_n, f, g 在 N 上都改为 0。这些函数仍可测且积分不变, 因而下述关系可以按逐点意义使用。由 $|f_n| \leq g$ 并取逐点极限可得 $|f| \leq g$ 几乎处处, 所以 f 可积。函数 $g + f_n$ 与 $g - f_n$ 均非负。对它们分别使用 Fatou 引理,

$$\begin{aligned} \int g + \int f &\leq \int g + \liminf_{n \rightarrow \infty} \int f_n, \\ \int g - \int f &\leq \int g - \limsup_{n \rightarrow \infty} \int f_n. \end{aligned}$$

由于 $\int g < \infty$, 可以从两边减去它, 得到

$$\int f \leq \liminf_n \int f_n \leq \limsup_n \int f_n \leq \int f.$$

故积分收敛到 $\int f$ 。

最后, $|f_n - f| \rightarrow 0$ 几乎处处, 且 $|f_n - f| \leq 2g$ 。再对非负函数 $|f_n - f|$ 应用刚证明的积分交换结论, 得到 $\int |f_n - f| d\mu \rightarrow 0$ 。 ■

收缩峰 $f_n = n\mathbb{I}_{(0,1/n)}$ 不存在满足条件的可积控制函数。若 $g \geq f_n$ 几乎处处对每个 n 成立, 先把可数个例外集并为 N 。对 $x \in (0, 1/4) \setminus N$ 取

$n = [1/(2x)]$, 则 $n < 1/x$ 且 $n \geq 1/(4x)$, 从而 $g(x) \geq f_n(x) = n \geq 1/(4x)$ 。这个下界在 0 附近不可积, 说明失效的是统一可积控制, 而不是逐点极限。

贡献还可能逃向无穷远。在 $\mathbb{R}$ 上取 $f_n = \mathbb{I}_{[n, n+1)}$, 则 $f_n \rightarrow 0$ 处处成立, 积分却恒为 1。若有共同支配 g , 它须在 $[1, \infty)$ 上几乎处处至少为 1, 不可能可积。可积支配同时排除这种向远处移动和前面的局部集中; 单纯给出统一常数上界, 在无限测度空间上还不够。

反过来, 在 $(0, 1)$ 上取 $f_n(x) = x^n/\sqrt{x}$, 则逐点趋于零, 且 $|f_n| \leq x^{-1/2}$, 右侧已知可积。DCT 给出 $\int f_n \rightarrow 0$; 直接积分得到 $1/(n+1/2)$, 核对了结论。支配函数可以无界, 需要有限的是它的积分, 而不是普通上确界。

交换符号之前可以按表 3.2 核对实际使用的定理。“有极限”只提供一个候选函数, 附加条件才保证整体量在取极限时被保留下来。

结果	核对的条件	可得到的结论
单调收敛	非负可测函数逐点或几乎处处递增	极限与积分相等, 允许无穷值
Fatou 引理	非负可测函数列	先取下极限再积分, 不超过先积分再取下极限的结果
支配收敛	几乎处处收敛, 且共用一个可积绝对上界	积分可交换极限, 并有 $\int f_n - f d\mu \rightarrow 0$
Tonelli 定理	σ 有限乘积测度上的非负可测函数	交换积分次序, 允许无穷值
Fubini 定理	σ 有限乘积测度上的绝对可积函数	交换积分次序, 并得到有限积分

表 3.2 极限与积分、积分与积分之间的交换条件。表中的测度、可测性和统一控制属于结论的假设。

3.5.4.3 参数求导与积分交换

给定参数以后, $g(\cdot, \theta)$ 是一个函数; 让参数接近 θ_0 时, 差商形成一族逼近函数。因此积分号下求导同时使用第 3.3 节的微分、第 3.4 节的积分, 以及刚证明的支配收敛, 不能只由各点偏导数存在就交换运算。

设

$$G(\theta) = \int_X g(x, \theta) d\mu(x).$$

形式上希望把导数移入积分号:

$$G'(\theta) \stackrel{?}{=} \int_X \frac{\partial g}{\partial \theta}(x, \theta) d\mu(x).$$

真正需要交换的是差商的极限与积分。固定 θ_0 , 设对每个 $\theta \in I$, $x \mapsto g(x, \theta)$ 可测, 其中 I 是包含 θ_0 的开区间, 并且 $g(\cdot, \theta_0)$ 可积。假设存在一个可测零测集 N , 使每个 $x \notin N$ 处的 $\theta \mapsto g(x, \theta)$ 在整个 I 内可微; 对每个 θ , 偏导数作为 x 的函数可测, 并且存在非负可积函数 h 使

$$\left| \frac{\partial g}{\partial \theta}(x, \theta) \right| \leq h(x) \quad \text{对所有 } x \notin N \text{ 及所有 } \theta \in I \text{ 成立,} \quad (3.45)$$

这里 N 和 h 都不能随参数 θ 改变; 参数不可数, 不能靠取所有参数例外集的并自动获得一个零测集。中值定理先给出 $|g(x, \theta) - g(x, \theta_0)| \leq |\theta - \theta_0| h(x)$,

所以 I 中每个 $g(\cdot, \theta)$ 都可积, G 在邻域内有有限值。对非零 t 且 $\theta_0 + t \in I$, 令

$$q_t(x) = \frac{g(x, \theta_0 + t) - g(x, \theta_0)}{t}.$$

中值定理又给出 $|q_t(x)| \leq h(x)$ 于 $X \setminus N$ 。差商在那里趋于 $\partial g / \partial \theta(x, \theta_0)$ 。对任意非零序列 $t_n \rightarrow 0$ 应用支配收敛, 得到同一个积分极限; 由实数极限的序列判据, 这就是 $t \rightarrow 0$ 的双侧极限。因此

$$G'(\theta_0) = \int_X \frac{\partial g}{\partial \theta}(x, \theta_0) d\mu(x). \quad (3.46)$$

条件 (3.45) 是一个便于核对的充分条件; 更一般的版本可以直接控制差商, 或使用其他一致可积条件。

例如令 $g(x, \theta) = e^{-\theta x}$, $x \in [0, \infty)$, $\theta > 0$, 并用 Lebesgue 测度积分。固定 $\theta_0 > 0$ 后取 $I = (\theta_0/2, 3\theta_0/2)$, 则 $|\partial_\theta g| = xe^{-\theta x} \leq xe^{-\theta_0 x/2} =: h(x)$ 。分部积分给出 $\int_0^\infty h(x) dx = 4/\theta_0^2 < \infty$, 没有需要删除的例外点, 故 $G'(\theta_0) = -\int_0^\infty xe^{-\theta_0 x} dx = -1/\theta_0^2$, 与 $G(\theta) = 1/\theta$ 的直接求导一致。若把参数范围放大到任意接近零的正数, 便不能沿用这个固定的控制函数; 交换结论所需的是所考察参数点附近的统一控制。

示例 3.56 参数积分中的控制函数失效 下面考察参数域边界处对应的右求导问题。对 $\theta \geq 0$ 与 $x \in (0, 1)$, 定义

$$g(x, \theta) = \begin{cases} \frac{\theta x}{x^2 + \theta^2}, & \theta > 0, \\ 0, & \theta = 0. \end{cases}$$

每个固定 $x > 0$ 处关于 θ 的右偏导数都等于 $1/x$, 但 $1/x$ 在 $(0, 1)$ 上不可积。直接积分得到

$$G(\theta) = \frac{\theta}{2} \log \left(\frac{1 + \theta^2}{\theta^2} \right) \quad (\theta > 0), \quad G(0) = 0.$$

于是 $G(\theta)/\theta$ 在 $\theta \downarrow 0$ 时发散, G 在 0 处没有有限右导数。积分内的逐点右导数虽然存在, 却缺少统一可积控制; 因此, 逐点右导数的存在没有保证积分函数具有有限右导数, 也不满足前面交换求导与积分的条件。

3.6 本章小结

章首问: 每步误差减小, 能否保证最终得到准确答案? 答案取决于减小的方式与误差怎样累计。单项趋零不保证累计误差有限; 压缩迭代通过几何衰减控制整个尾部, 再由空间完备性保证极限存在并仍在空间内。这个极

限满足更新方程，压缩条件还保证解唯一，并提供有限步停止时的误差界。比较误差前必须选定距离；累计贡献前必须选定测度。测度的完备化处理零测集的子集，度量的完备性处理柯西列的极限，二者解决的问题不同。

固定一个函数以后，连续性控制输入扰动，微分提供局部线性模型，二阶信息与 Taylor 余项说明曲率及近似损失。隐函数定理把方程的局部解建立为可微函数，使解导数与最优值的包络导数能够区分。尖点、跳跃和替代更新信号又说明，真实导数、广义梯度与人为指定的反向信号必须分别判断。

整体累计依赖可测范围和权重。简单函数把积分还原为有限贡献，单调逼近进入一般非负函数，绝对可积性排除正负无穷相消；积分只有在总权重为 1 或完成归一化后才是平均。乘积测度、换元与边界公式各自改变累计的对象或表示，积分次序、体积修正与边界项都有明确条件，不能由有限和的操作习惯直接代替。

章首另一个问题是：各处函数值越来越准确，能否保证积分也越来越准确？逐点收敛做不到这一点，因为峰可以变窄并同时增高，也可以向无穷远移动。非负单调性或共同的可积支配给出了可以交换极限与积分的条件。一致收敛能保留连续性，却仍不能自动保留导数。积分号下求导还需要同时控制差商的极限和积分误差。因此，使用一个极限结论前，应先说明要控制函数值、导数还是积分，再核对相应条件。第 4 章据此研究最优性与求解，第 5 章进一步研究函数空间中的表示、逼近和稳定性。

第 4 章

最优化

设想我们要用一组参数拟合数据，同时不能超出给定的资源预算。试过一组参数后，梯度可以告诉我们附近哪个方向会降低误差，但还没有回答两个问题：是否有更好的允许参数，以及怎样在有限计算时间内找到它。第 3 章研究的局部变化，将在本章用来解决这个整体选择问题。贯穿全章的对象是带正则项的最小二乘

$$F(\mathbf{w}) = \frac{1}{2n} \|\mathbf{X}\mathbf{w} - \mathbf{y}\|_2^2 + \frac{\lambda}{2} \|\mathbf{w}\|_2^2, \quad \mathbf{X} \in \mathbb{R}^{n \times d}, \quad \lambda \geq 0, \quad (4.1)$$

其中 $\mathbf{X}$ 的第 i 行记录第 i 个样本的输入， $\mathbf{y}$ 记录对应的观测结果， $\mathbf{w}$ 是待选择的参数。第一项比较预测 $\mathbf{X}\mathbf{w}$ 与观测的差距，第二项让幅度较大的参数付出额外代价。若还要求参数满足资源预算，就加入线性约束

$$\mathbf{A}\mathbf{w} = \mathbf{b}, \quad \mathbf{G}\mathbf{w} \leq \mathbf{h}. \quad (4.2)$$

式 (4.1) 与第 1 章的式 (1.1) 是同一个目标的矩阵写法。正则项改变候选参数的代价，资源约束改变允许采用的参数范围：一个参数即使被正则项加重了代价，仍然可以被选择；违反硬约束的参数则被直接排除。

给定目标、可行范围和计算预算，本章要回答怎样构造一个足够好的解，以及怎样核验它。先建立解与误差的共同语言，再依次讨论无约束光滑、无约束非光滑和有约束问题的基本更新。如果每轮求解太贵，可以暂时放宽约束、求解一个更简单的替代目标、每次只更新一组变量，或者只读取部分数据。这些做法分别省去了什么计算、引入了什么误差，必须说清楚。如果任务同时追求多个指标、要应对最坏扰动，或要评价另一次优化的结果，还需先规定怎样比较候选，再选择算法。这些做法可以组合使用。比较算法时，除了上述拟合与资源例，还固定使用小二次目标

$$f(\mathbf{w}) = \frac{1}{2}(w_1^2 + 16w_2^2), \quad \mathbf{H} = \text{diag}(1, 16), \quad \mathbf{w}^{(0)} = (2, 2)^\top. \quad (4.3)$$

其最小点为零、初始目标值为 34；两方向曲率的差异使方向、步长和每步成本都能直接核算。

4.1 优化问题的定义与基本性质

设计求解算法之前，需要分清三件事：问题是否有解、怎样认出最优解，以及局部信息能否保证全局最优。要保证解存在，关键是候选趋近极限时，极限仍被允许且目标值不突然变差；凸性和其他曲率条件则帮助判断驻点是否最优、解是否唯一，以及近似解偏差有多大。这些是后面各种算法共用的前提，不是三种求解方法。

4.1.1 优化问题与解

一个优化问题必须同时给出目标函数、变量和可行域。记

$$\min_{\mathbf{w} \in C} F(\mathbf{w}), \quad C = \{\mathbf{w} \in \mathbb{R}^d : \mathbf{A}\mathbf{w} = \mathbf{b}, \mathbf{G}\mathbf{w} \leq \mathbf{h}\}.$$

变量 $\mathbf{w}$ 是待选择的参数，目标 F 规定怎样比较候选，可行域 C 规定哪些候选允许采用。若等式有 m 条、不等式有 p 条，则 $\mathbf{A} \in \mathbb{R}^{m \times d}$ 、 $\mathbf{b} \in \mathbb{R}^m$ 、 $\mathbf{G} \in \mathbb{R}^{p \times d}$ 、 $\mathbf{h} \in \mathbb{R}^p$ ，向量不等式逐坐标理解。若 $C = \emptyset$ ，问题不可行 (infeasible)；若 $C \neq \emptyset$ 但 $\inf_{\mathbf{w} \in C} F(\mathbf{w}) = -\infty$ ，问题无下界 (unbounded below)。当问题可行且有有限下界时，还要问：有没有一个允许的参数，能真正达到这个下确界？例如同时要求 $x \leq 0$ 和 $x \geq 1$ 就不可行；在实线上最小化 x 无下界， $\inf_{x \in \mathbb{R}} e^x = 0$ 有下界却没有最小点；把 x 限制在 $[0, 1]$ 后，后一问题的最小值变为 1 且在 0 达到。最优值是数 $F^* = \inf_C F$ ，最优解集合是 $\arg \min_C F$ ，后者可以为空或包含多个点。写出问题 $\min_C F$ 表示求最小值的任务，并不代替存在性证明；声称某个数等于 $\min_C F$ 时，才需要确认它确实被可行点取得。

定义 4.1 全局解、局部解与无约束驻点 设 $C \subseteq \mathbb{R}^d$ 非空， $F : C \rightarrow \mathbb{R}$ 。全局最优解 (global minimizer) $\mathbf{w}^* \in C$ 满足 $F(\mathbf{w}^*) \leq F(\mathbf{w})$ 对所有 $\mathbf{w} \in C$ 成立。局部最优解 (local minimizer) 要求存在 $r > 0$ ，使该不等式对所有 $\mathbf{w} \in C \cap B(\mathbf{w}^*, r)$ 成立。无约束可微问题的驻点 (stationary point) 满足 $\nabla F(\mathbf{w}) = \mathbf{0}$ 。驻点只是局部一阶变化消失，可能是极小点、极大点或第 3.3.3 节所说的微分鞍点。

给定 $\varepsilon > 0$ 和可行候选 $\hat{\mathbf{w}} \in C$ ，若

$$F(\hat{\mathbf{w}}) - \inf_{\mathbf{w} \in C} F(\mathbf{w}) \leq \varepsilon,$$

就称 $\hat{\mathbf{w}}$ 为目标值意义下的 ε 近似解。对无约束可微问题，另一种常见标准是 $\|\nabla F(\hat{\mathbf{w}})\|_2 \leq \varepsilon$ ；在没有额外曲率条件时，这两种近似不能互换。一般约束问题的精确最优解也可能有非零梯度；后面的约束求解将建立同时反映允许移动方向与可行性的停止标准。

前面的目标值近似标准只比较目标与最优值之间的差距。评价同一个近似参数时，还可以关心它离某个参照参数多远，或者它的预测发生了多大变化。因此，需要分别计算目标值的差、参数之间的距离和预测之间的差。下面暂取 $C = \mathbb{R}^d$ ，不加资源约束，以式 (4.1) 为目标。令 $F^* = \inf_{\mathbf{w} \in \mathbb{R}^d} F(\mathbf{w})$ ；若选定一个最小点 $\mathbf{w}^*$ ，则

$$F(\hat{\mathbf{w}}) - F^*, \quad \|\hat{\mathbf{w}} - \mathbf{w}^*\|_2, \quad \left(\frac{1}{n} \sum_{i=1}^n (\hat{\mathbf{w}}^\top \mathbf{x}_i - (\mathbf{w}^*)^\top \mathbf{x}_i)^2 \right)^{1/2}$$

分别是目标值误差、参数误差和在给定样本输入上的预测误差。最小点不唯一时，参数误差还需要指定参照解，或改成到最小点集合的距离。三种误差衡量不同对象，彼此能否控制取决于目标曲率、数据矩阵和参数化；一个误差较小不能无条件推出另两个也较小。

例如，在 $n = 1$ 、 $\mathbf{x}_1 = (1, 0)^\top$ 、 $y_1 = 0$ 、 $\lambda = 0$ 时，目标函数为 $F(w_1, w_2) = w_1^2/2$ 。参照解 $(0, 0)$ 与参数 $(0, 100)$ 的目标值都为 0，在这个样本输入上的预测也相同，参数距离却是 100。差别来自目标和当前观测都没有约束第二个坐标；并不是把目标误差算得更精确就能补回这项信息。

若希望在一个目标式中同时比较代价并排除不可行点，可以约定不可行点的代价为 $+\infty$ 。这种扩展实值表达把约束并入函数，后面的非光滑子问题就不必另写一套可行域符号。

定义 4.2 适当函数、有效定义域与约束指标 函数 $f : \mathbb{R}^d \rightarrow \mathbb{R} \cup \{+\infty\}$ 若不恒为 $+\infty$ ，称为适当函数；它从不取 $-\infty$ 。其有效定义域 (effective domain) 为 $\text{dom } f = \{\mathbf{x} : f(\mathbf{x}) < +\infty\}$ 。集合 C 的扩展实值指标函数为 $\iota_C(\mathbf{x}) = 0$ ($\mathbf{x} \in C$)，在其余点取 $+\infty$ 。

这个指标不是第 1 章取 0/1 的指示函数。它把不允许的点排除出最小化，而不只是给集合成员作标记。于是 $\min_{\mathbf{w} \in C} F(\mathbf{w})$ 可统一写成 $\min_{\mathbf{w} \in \mathbb{R}^d} \{F(\mathbf{w}) + \iota_C(\mathbf{w})\}$ 。有限惩罚会增加违规候选的代价，它仍可能胜过其他候选；取 $+\infty$ 才真正将它排除。有效定义域记录有有限代价的点，适当性保证至少还有一个这样的点；它不保证有下界、更不保证最小值达到。

4.1.2 最优解的存在

即使暂时不知道如何求解，也能选择一系列目标值越来越接近下确界的候选，称为最小化序列。有限下确界 m 时，可逐项选取 $F(\mathbf{w}^{(k)}) \leq m + 1/k$ ；若下确界为 $-\infty$ ，则可逐项要求 $F(\mathbf{w}^{(k)}) \leq -k$ 。要从这些候选得到最优点，须回答三个问题：序列能否取到收敛子列，极限是否仍可行，目标值比较

能否传到极限。若 $C \subseteq \mathbb{R}^d$ 非空且紧, $F : C \rightarrow \mathbb{R}$ 连续, 则定理 3.24 保证 F 在 C 上达到全局最小值。这里直接复用第 3 章的极值存在结论。

可行域不紧时, 候选可能越走越远, 永远没有收敛子列。若目标在远处变得很大, 接近最优值的候选就不能逃向无穷远。另一个障碍是: 候选已收敛, 极限点的目标值却突然高于邻近值。下面的强制性排除前一种障碍, 下半连续性排除后一种障碍。

定义 4.3 强制性与下半连续性 设 $C \subseteq \mathbb{R}^d$, $F : C \rightarrow (-\infty, +\infty]$ 。若沿 C 中的任意序列, $\|\mathbf{w}\|_2 \rightarrow \infty$ 时 $F(\mathbf{w}) \rightarrow \infty$, 称 F 是强制的 (coercive)。 F 在 C 上下半连续 (lower semicontinuous) 要求对每个收敛序列 $\mathbf{w}^{(k)} \rightarrow \mathbf{w}$ 都有

$$F(\mathbf{w}) \leq \liminf_{k \rightarrow \infty} F(\mathbf{w}^{(k)}).$$

其中序列与极限点均属于 C 。

连续性并不是存在性证明所需的最弱条件。下半连续性允许函数值在极限点向下跳, 却不允许极限点的函数值突然高于邻近值。等价地, 每个下水平集 $\{\mathbf{w} \in C : F(\mathbf{w}) \leq a\}$ 在 C 的相对拓扑中都是闭集。

设 C 非空且闭, $F : C \rightarrow (-\infty, +\infty]$ 下半连续、强制, 并且不恒为 $+\infty$ 且从不取 $-\infty$ 。取 $\bar{\mathbf{w}} \in C$ 使 $F(\bar{\mathbf{w}}) < +\infty$, 再把最小化序列限制到下水平集

$$K = \{\mathbf{w} \in C : F(\mathbf{w}) \leq F(\bar{\mathbf{w}})\}.$$

若 $\inf_C F = F(\bar{\mathbf{w}})$, 则 $\bar{\mathbf{w}}$ 已经是最小点; 否则 $\inf_C F < F(\bar{\mathbf{w}})$, 任一最小化序列从某项起都落入 K , 可以只保留这段尾序列。强制性使 K 有界, 下半连续性与 C 的闭性使 K 闭, 故 K 在有限维空间中紧。该尾序列有子列收敛到 $\mathbf{w}^* \in K$, 而下半连续性给出 $F(\mathbf{w}^*) \leq \liminf_k F(\mathbf{w}^{(k)}) = \inf_C F$ 。因此下确界达到。若原先假设下确界为 $-\infty$, 同一不等式会迫使 $F(\mathbf{w}^*) = -\infty$, 与适当性矛盾; 所以这些条件也排除了无下界情形。这个证明也指出各条件的职责: 强制性阻止序列逃向无穷远, 闭性保留可行极限, 下半连续性把目标值比较传到极限点。回到拟合数据的目标, 当 $\lambda > 0$ 时, 式 (4.1) 满足 $F(\mathbf{w}) \geq \lambda \|\mathbf{w}\|_2^2/2$, 所以即使可行域无界也不会沿参数无穷大的方向降低目标。

4.1.3 凸性与最优解的性质

4.1.3.1 凸性与全局最优

若一个局部低点不是全局低点, 能否沿可行路径走向更低处? 凸性让两点间的线段成为这条路径, 并控制沿途的目标值; 这正是局部判优能够升级

为全局判优的原因。约束只告诉我们哪些点允许使用；还要问两个可行点之间能否连续移动而始终可行。

定义 4.4 凸集与凸函数 集合 $C \subseteq \mathbb{R}^d$ 为凸集 (convex set), 是指对任意 $\mathbf{u}, \mathbf{v} \in C$ 和 $\theta \in [0, 1]$, $\theta\mathbf{u} + (1 - \theta)\mathbf{v} \in C$ 。线性等式、线性不等式和范数球的解集都是凸集, 它们的交集仍为凸集, 所以式 (4.2) 定义凸可行域。

定义在凸集 C 上的函数 $f: C \rightarrow \mathbb{R}$ 若对任意 $\mathbf{u}, \mathbf{v} \in C$ 和 $\theta \in [0, 1]$ 满足

$$f(\theta\mathbf{u} + (1 - \theta)\mathbf{v}) \leq \theta f(\mathbf{u}) + (1 - \theta)f(\mathbf{v}), \quad (4.4)$$

就称为凸函数 (convex function)。若 $-f$ 凸, 则称 f 凹。

凸函数的图像在两端点之间不超过连接它们的弦。如果远处有一个更低的点, 沿线段靠近当前点的位置也会更低, 因此当前点不能是局部最小点。稍后将用这个思路证明局部最优也是全局最优¹。

¹ S. Boyd, L. Vandenberghe, *Convex Optimization*, Cambridge University Press, 2004

定理 4.5 凸函数的一阶与二阶判据 设 C 为开凸集。可微函数 $f: C \rightarrow \mathbb{R}$ 凸, 当且仅当对任意 $\mathbf{u}, \mathbf{v} \in C$,

$$f(\mathbf{v}) \geq f(\mathbf{u}) + \langle \nabla f(\mathbf{u}), \mathbf{v} - \mathbf{u} \rangle. \quad (4.5)$$

若 f 二阶可微, 则这又等价于 $\nabla^2 f(\mathbf{w}) \geq \mathbf{0}$ 对所有 $\mathbf{w} \in C$ 成立。

证明. 若 f 凸, 令 $\phi(t) = f(\mathbf{u} + t(\mathbf{v} - \mathbf{u}))$ 。由凸性, $[\phi(t) - \phi(0)]/t \leq \phi(1) - \phi(0)$ 。令 $t \downarrow 0$ 便得式 (4.5)。反过来, 令 $\mathbf{z} = \theta\mathbf{u} + (1 - \theta)\mathbf{v}$, 分别把一阶不等式用于 $(\mathbf{z}, \mathbf{u})$ 和 $(\mathbf{z}, \mathbf{v})$, 乘以 θ 与 $1 - \theta$ 后相加, 线性项抵消, 得到式 (4.4)。

若 f 凸, 把一阶判据用于 $\mathbf{w}$ 与 $\mathbf{w} + t\mathbf{v}$, 再对 t 求二阶局部极限, 得到 $\mathbf{v}^\top \nabla^2 f(\mathbf{w}) \mathbf{v} \geq 0$ 。反之, 沿任意线段定义 $\phi(t)$, 则 $\phi''(t) = (\mathbf{v} - \mathbf{u})^\top \nabla^2 f(\mathbf{u} + t(\mathbf{v} - \mathbf{u}))(\mathbf{v} - \mathbf{u}) \geq 0$, 一元函数 ϕ 凸, 故 f 凸。■

反复应用二点凸性可得 Jensen 不等式 (Jensen's inequality)。若 $\alpha_i \geq 0$ 且 $\sum_i \alpha_i = 1$, 则

$$f\left(\sum_{i=1}^m \alpha_i \mathbf{w}_i\right) \leq \sum_{i=1}^m \alpha_i f(\mathbf{w}_i). \quad (4.6)$$

归纳步骤把前 $m - 1$ 个点先归一化为一个加权平均, 再与第 m 个点应用二点凸性。具体地, 若 $\alpha_m < 1$, 取 $\mathbf{z} = \sum_{i < m} \alpha_i \mathbf{w}_i / (1 - \alpha_m)$, 归纳假设给 $f(\mathbf{z}) \leq \sum_{i < m} \alpha_i f(\mathbf{w}_i) / (1 - \alpha_m)$; 再用于 $(1 - \alpha_m)\mathbf{z} + \alpha_m \mathbf{w}_m$ 即可。若 $\alpha_m = 1$, 结论直接为等式。这里要求非负权重且权重和为 1, 是为了让加权平均仍

在线段组合形成的范围内；允许负权重后，组合点可能落到这个范围之外，因而不能再由凸性保证 Jensen 不等式。

凸性还把最优性变成可核验的一阶条件。若 f 可微且凸，则 $\nabla f(\mathbf{w}^*) = \mathbf{0}$ 代入式 (4.5) 使得 $f(\mathbf{v}) \geq f(\mathbf{w}^*)$ 。因此凸问题的驻点是全局最小点。更一般地，凸集 C 上凸函数的每个局部最小点都是全局最小点，不要求可微：若 $\mathbf{u}$ 局部最优而某个 $\mathbf{v} \in C$ 满足 $f(\mathbf{v}) < f(\mathbf{u})$ ，则对任意 $t \in (0, 1)$ ， $\mathbf{u} + t(\mathbf{v} - \mathbf{u}) \in C$ 且 $f(\mathbf{u} + t(\mathbf{v} - \mathbf{u})) \leq (1 - t)f(\mathbf{u}) + tf(\mathbf{v}) < f(\mathbf{u})$ 。取足够小的 t 便与局部最优矛盾。对于边界上的约束最优点，仍不能反推普通梯度为零。图 4.1 同时画出这两侧的界。弦在图像上方，源于二点凸组合；切线在图像下方，源于可微凸函数的一阶判据。二者夹住函数，却来自不同的比较对象，不能把某点处的切线误当作连接两个函数值的弦。




图 4.1 $f(x) = x^2/2$ 的弦与切线。蓝线为函数，红线连接 $u = -1$ 与 $v = 2$ 的函数值，在这两个输入之间给出弦上界；黄虚线是在 $x_0 = 1/2$ 处的一阶仿射下界，适用于整个实线。红线的上界只在其端点之间使用，切线下界来自凸性。图为解析教学示例。

对扩展实值目标，式 (4.4) 在有限取值的点上检验，并要求有效定义域凸；这避免在端点权重为零时操作 $0 \cdot (+\infty)$ 。

4.1.3.2 严格凸性与解的唯一性

凸函数可以沿某个方向保持不变，局部到全局的保证并没有排除多个最小点。若希望排除这种平坦的最优线段，需要把不同点之间的凸性不等式加强为严格不等式。

定义 4.6 严格凸函数 设 C 凸, $f: C \rightarrow \mathbb{R}$. 若式 (4.4) 对所有 $\mathbf{u} \neq \mathbf{v}$ 及 $0 < \theta < 1$ 严格成立, 则称 f 严格凸。

若两个不同点 $\mathbf{u}, \mathbf{v}$ 都达到最小值 m , 严格凸性使其中点的函数值严格小于 $(m + m)/2 = m$, 矛盾。因此它只保证至多一个最小点; 严格凸函数 e^x 在实线上仍没有最小点。存在性必须另由前一小节的条件检验。在式 (4.1) 中, $\lambda = 0$ 且 $\mathbf{X}$ 不满列秩时沿零空间方向目标不变; $\mathbf{X}$ 满列秩或 $\lambda > 0$ 时, 任意非零方向 $\mathbf{d}$ 都有 $\|\mathbf{X}\mathbf{d}\|_2^2/n + \lambda\|\mathbf{d}\|_2^2 > 0$, 故目标严格凸。与闭可行域上的存在性合用, 才能断言有唯一解。

4.1.3.3 强凸性与误差控制

严格凸性排除了多个最小点, 却还不能回答: 目标值只比最优值高一点, 参数是否也离最优点很近? 若目标在最优点附近很平坦, 目标差很小也可能对应较大的参数距离。为控制这种情况, 强凸性要求弦段与函数之间至少留出一个与两端距离平方成比例的间隔。这个条件也能用于有尖角的函数, 并可按不同范数衡量距离。

定义 4.7 相对于范数的强凸性 设 C 是实赋范空间中的凸集, $f: C \rightarrow \mathbb{R}$, $\mu > 0$. 若对任意 $\mathbf{u}, \mathbf{v} \in C$ 和 $\theta \in [0, 1]$ 都有

$$f(\theta\mathbf{u} + (1-\theta)\mathbf{v}) \leq \theta f(\mathbf{u}) + (1-\theta)f(\mathbf{v}) - \frac{\mu}{2}\theta(1-\theta)\|\mathbf{u} - \mathbf{v}\|^2, \quad (4.7)$$

则称 f 相对于 $\|\cdot\|$ 是 μ 强凸 (μ -strongly convex) 的。

在欧氏空间的开凸集上, 若 f 可微, 强凸性等价于一阶下界

$$f(\mathbf{v}) \geq f(\mathbf{u}) + \langle \nabla f(\mathbf{u}), \mathbf{v} - \mathbf{u} \rangle + \frac{\mu}{2}\|\mathbf{v} - \mathbf{u}\|_2^2. \quad (4.8)$$

可用定理 4.5 对 $f(\mathbf{w}) - \mu\|\mathbf{w}\|_2^2/2$ 应用凸性判据得到这一等价关系; 若 f 二阶可微, 它又等价于 $\nabla^2 f(\mathbf{w}) \geq \mu\mathbf{I}$ 。一般范数的平方未必是欧氏二次型, 因此不能把这一 Hessian 写法直接当作所有范数下的定义。例如 $|x| + \mu x^2/2$ 虽在 0 处不可微, 仍相对于绝对值范数 μ 强凸: 绝对值部分满足凸性, 二次部分恰好提供式 (4.7) 中的距离平方间隔。

强凸性还能把目标差转成参数距离。设 f 在凸集 C 上 μ 强凸, 且最小点 $\mathbf{w}^*$ 存在。把定义用于 $\mathbf{w}^*$ 与任意 $\mathbf{w} \in C$, 并用最优性给线段上的函数值加下界, 得到

$$f(\mathbf{w}^*) \leq (1-t)f(\mathbf{w}^*) + tf(\mathbf{w}) - \frac{\mu}{2}t(1-t)\|\mathbf{w} - \mathbf{w}^*\|^2.$$

除以 $t > 0$ 再令 $t \downarrow 0$, 可得

$$f(\mathbf{w}) - f(\mathbf{w}^*) \geq \frac{\mu}{2} \|\mathbf{w} - \mathbf{w}^*\|^2, \quad \|\mathbf{w} - \mathbf{w}^*\| \leq \sqrt{\frac{2(f(\mathbf{w}) - f^*)}{\mu}}. \quad (4.9)$$

证明并未假设最优点在内部, 因此也适用于固定凸域上的非光滑目标。

目标稍有变化时, 最优参数会移动多远? 下面只改变目标的线性项, 并保持同一个凸集 C , 用欧氏范数衡量移动距离: $f_b(\mathbf{w}) = f(\mathbf{w}) - \langle \mathbf{b}, \mathbf{w} \rangle$ 。设 $\mathbf{w}_b$ 与 $\mathbf{w}_c$ 分别达到这两个强凸问题的最小值。把式 (4.9) 分别用于两个目标后相加, 得

$$\mu \|\mathbf{w}_b - \mathbf{w}_c\|_2^2 \leq \langle \mathbf{b} - \mathbf{c}, \mathbf{w}_b - \mathbf{w}_c \rangle, \quad \|\mathbf{w}_b - \mathbf{w}_c\|_2 \leq \frac{\|\mathbf{b} - \mathbf{c}\|_2}{\mu}.$$

这里没有改变可行域, 也没有任意改变目标的曲率。约束边界变化造成的活跃集切换, 不能由这个线性扰动界一并处理。

式 (4.1) 的 Hessian 矩阵为 $\mathbf{X}^\top \mathbf{X}/n + \lambda \mathbf{I}$ 。当 $\lambda > 0$ 时, 正则项把所有缺失曲率的方向至少抬高到 λ , 因而目标 λ 强凸。若 $\lambda = 0$ 且 $\mathbf{X}$ 不满列秩, 驻点仍是全局最优点, 但解不唯一; 若目标再加入非凸项, 驻点甚至不再保证局部最小。

前述零空间退化满足 $F(\mathbf{w} + t\mathbf{v}) = F(\mathbf{w})$, 说明曲率缺失可以产生多个解。即使曲率处处为正且解唯一, 数值问题也可能非常敏感。例如令 $0 < \epsilon \ll 1$ 并考虑

$$f_b(w_1, w_2) = \frac{1}{2}(\epsilon w_1^2 + w_2^2) - bw_1.$$

它对每个 b 都有唯一最小点 $(b/\epsilon, 0)$, 但 b 改变 Δb 会使第一坐标改变 $\Delta b/\epsilon$ 。更一般的二次目标具有如下曲率矩阵:

$$\mathbf{H} = \frac{1}{n} \mathbf{X}^\top \mathbf{X} + \lambda \mathbf{I}$$

当 $\mathbf{H} > \mathbf{0}$ 时, 若线性项受到加性扰动 $\delta \mathbf{g}$, 相应解变化满足

$$\|\delta \mathbf{w}\|_2 \leq \frac{1}{\lambda_{\min}(\mathbf{H})} \|\delta \mathbf{g}\|_2.$$

因此 $1/\lambda_{\min}(\mathbf{H})$ 控制固定尺度加性扰动的绝对放大; 经过目标和变量尺度归一化后, 条件数 $\kappa(\mathbf{H}) = \lambda_{\max}(\mathbf{H})/\lambda_{\min}(\mathbf{H})$ 才反映不同方向对相对误差的放大差异。例如 $\mathbf{H} = \epsilon \mathbf{I}$ 的条件数为 1, 但绝对扰动仍会被放大 $1/\epsilon$ 倍。唯一性回答“解有几个”, 敏感性还取决于所采用的扰动尺度, 不能只由唯一性或条件数笼统判断。

4.2 无约束光滑目标的求解

知道怎样判断最优点以后，还要回答怎样从初始参数走向它。这里先考虑可微且梯度光滑的目标：梯度下降用一阶信息保证单步改善，动量和预条件再利用迭代历史或曲率改变移动方向。判断这些方法是否收敛、能快多少，需要同时说明目标满足哪些曲率条件。仅看更新公式还不能比较快慢。

4.2.1 一阶方法

在每个候选处只计算目标的一阶变化，就能以较少的局部信息构造方向。梯度下降使用当前点的梯度；动量和加速还保留历史信息，但每轮仍只要求一次梯度计算。

4.2.1.1 梯度下降

当前梯度只描述附近的变化。若走出很短一段距离后，梯度已经大幅改变，按旧方向迈出的一步就可能越过低点，甚至使目标上升。要选择有保证的步长，需要给梯度的变化速度设上界。

定义 4.8 欧氏梯度光滑性 设 $C \subseteq \mathbb{R}^d$ 开且凸， $f : C \rightarrow \mathbb{R}$ 可微， $L \geq 0$ 有限。 f 为 L 光滑 (L -smooth)，是指对任意 $\mathbf{u}, \mathbf{v} \in C$ ，梯度满足 $\|\nabla f(\mathbf{u}) - \nabla f(\mathbf{v})\|_2 \leq L\|\mathbf{u} - \mathbf{v}\|_2$ 。

这里限制的是两点梯度的差，而非两点函数值的差。强凸性让目标不会过于平坦，梯度光滑性让梯度不会变化过快；它们解决的是不同问题。例如， x^4 严格凸但不在全实线上强凸，也不在全实线上具有有限的光滑常数。

梯度给出最陡的一阶下降方向，但一步走多远取决于函数弯曲程度。光滑性把局部线性近似的余项控制为二次量²。本小节考虑可微函数 $f : \mathbb{R}^d \rightarrow \mathbb{R}$ ，并选取一个正的梯度 Lipschitz 上界 $L > 0$ 。若梯度恒定，仍可选择任意正上界；这样后面的 $1/L$ 步长也有定义。全空间的设定保证更新点仍在函数定义域内；若目标只定义在开凸子域上，使用下降引理时还须确认两端点及其线段留在该域内，不能直接把任意梯度步代入。

² J. Nocedal, S. J. Wright, *Numerical Optimization*, Springer, 2006, 2nd ed.

引理 4.9 下降引理 若 $f : \mathbb{R}^d \rightarrow \mathbb{R}$ 可微且梯度是 L -Lipschitz 连续的， $L > 0$ ，则对任意 $\mathbf{u}, \mathbf{v} \in \mathbb{R}^d$ ，

$$f(\mathbf{v}) \leq f(\mathbf{u}) + \langle \nabla f(\mathbf{u}), \mathbf{v} - \mathbf{u} \rangle + \frac{L}{2} \|\mathbf{v} - \mathbf{u}\|_2^2. \quad (4.10)$$

证明. 令 $\mathbf{d} = \mathbf{v} - \mathbf{u}$. 沿线段积分并减去一阶项可得

$$f(\mathbf{v}) - f(\mathbf{u}) - \langle \nabla f(\mathbf{u}), \mathbf{d} \rangle = \int_0^1 \langle \nabla f(\mathbf{u} + t\mathbf{d}) - \nabla f(\mathbf{u}), \mathbf{d} \rangle dt.$$

由 Cauchy-Schwarz 不等式和梯度 Lipschitz 条件, 被积函数至多为 $Lt\|\mathbf{d}\|_2^2$; 积分即得结论. ■

在当前点 $\mathbf{w}$, 一阶近似为 $f(\mathbf{w}) + \langle \nabla f(\mathbf{w}), \mathbf{d} \rangle$. 取 $\eta > 0$, 给这条近似加上控制移动幅度的 $\|\mathbf{d}\|_2^2/(2\eta)$, 其唯一最小增量是 $\mathbf{d} = -\eta \nabla f(\mathbf{w})$. 由此得到梯度下降更新:

$$\mathbf{w}^{(t+1)} = \mathbf{w}^{(t)} - \eta \nabla f(\mathbf{w}^{(t)}) \quad (4.11)$$

把 $\mathbf{v}$ 取为右端点代入下降引理, 得到

$$f(\mathbf{w}^{(t+1)}) \leq f(\mathbf{w}^{(t)}) - \eta \left(1 - \frac{L\eta}{2}\right) \|\nabla f(\mathbf{w}^{(t)})\|_2^2. \quad (4.12)$$

所以 $0 < \eta < 2/L$ 保证每个非驻点处严格下降. 若 f 下有界, 记其有限下确界为

$$f_{\inf} := \inf_{\mathbf{w} \in \mathbb{R}^d} f(\mathbf{w}) > -\infty.$$

取 $\eta = 1/L$ 并对 $t = 0, \dots, T-1$ 求和, 可得非凸光滑情形的保证

$$\min_{0 \leq t < T} \|\nabla f(\mathbf{w}^{(t)})\|_2^2 \leq \frac{2L(f(\mathbf{w}^{(0)}) - f_{\inf})}{T}. \quad (4.13)$$

它只说明某次迭代接近驻点, 没有声称驻点是全局最优点。

步长上界在一维二次函数上即可看到. 对 $f(w) = Lw^2/2$, $w^{(t+1)} = (1 - \eta L)w^{(t)}$. 当 $\eta = 2/L$ 时迭代在正负之间等幅振荡; $\eta > 2/L$ 时幅度按 $|1 - \eta L| > 1$ 增长. 负梯度方向本身没有错, 失败来自步长跨过了曲率允许的的稳定范围。

若 f 还凸、最小点 $\mathbf{w}^*$ 存在, 并继续取 $\eta = 1/L$, 则由凸性有 $f(\mathbf{w}^{(t)}) - f^* \leq \langle \nabla f(\mathbf{w}^{(t)}), \mathbf{w}^{(t)} - \mathbf{w}^* \rangle$. 先展开距离平方并使用这个不等式:

$$\begin{aligned} \|\mathbf{w}^{(t+1)} - \mathbf{w}^*\|_2^2 &= \|\mathbf{w}^{(t)} - \mathbf{w}^*\|_2^2 - \frac{2}{L} \langle \nabla f(\mathbf{w}^{(t)}), \mathbf{w}^{(t)} - \mathbf{w}^* \rangle \\ &\quad + \frac{1}{L^2} \|\nabla f(\mathbf{w}^{(t)})\|_2^2 \\ &\leq \|\mathbf{w}^{(t)} - \mathbf{w}^*\|_2^2 - \frac{2}{L} (f(\mathbf{w}^{(t)}) - f^*) \\ &\quad + \frac{1}{L^2} \|\nabla f(\mathbf{w}^{(t)})\|_2^2. \end{aligned}$$

另一方面, 把 $\eta = 1/L$ 代入式 (4.12) 可得

$$\frac{1}{L^2} \|\nabla f(\mathbf{w}^{(t)})\|_2^2 \leq \frac{2}{L} (f(\mathbf{w}^{(t)}) - f(\mathbf{w}^{(t+1)})).$$

用后一式消去梯度平方项，得到

$$\|\mathbf{w}^{(t+1)} - \mathbf{w}^*\|_2^2 \leq \|\mathbf{w}^{(t)} - \mathbf{w}^*\|_2^2 - \frac{2}{L}(f(\mathbf{w}^{(t+1)}) - f^*).$$

对 $t = 0, \dots, T-1$ 求和并去掉末端的非负距离，便有

$$\frac{2}{L} \sum_{t=0}^{T-1} (f(\mathbf{w}^{(t+1)}) - f^*) \leq \|\mathbf{w}^{(0)} - \mathbf{w}^*\|_2^2.$$

式 (4.12) 还说明目标值单调不增，因此左侧求和中的每一项都不小于 $f(\mathbf{w}^{(T)}) - f^*$ 。于是

$$f(\mathbf{w}^{(T)}) - f^* \leq \frac{L\|\mathbf{w}^{(0)} - \mathbf{w}^*\|_2^2}{2T}. \quad (4.14)$$

前面的梯度范数很小，只说明当前的一阶变化很小，尚不能判断目标离最优值多远。若希望用小梯度判断目标已经接近最优值，还需要把这两种量联系起来。Polyak-Łojasiewicz 条件 (PL condition) 直接要求这种联系，不要求函数必须凸。

定义 4.10 Polyak-Łojasiewicz 条件 设 $f : \mathbb{R}^d \rightarrow \mathbb{R}$ 可微， $f^* = \inf_{\mathbf{w}} f(\mathbf{w}) > -\infty$ 。若存在 $\mu > 0$ ，使任意 $\mathbf{w}$ 满足

$$\frac{1}{2}\|\nabla f(\mathbf{w})\|_2^2 \geq \mu(f(\mathbf{w}) - f^*), \quad \mu > 0. \quad (4.15)$$

则称 f 满足常数为 μ 的 PL 条件。

该条件把小梯度与小目标误差联系起来。强凸可推出 PL 条件：对 μ 强凸可微函数，把强凸下界右侧关于 $\mathbf{v}$ 最小化，得到

$$f^* \geq f(\mathbf{w}) - \frac{1}{2\mu}\|\nabla f(\mathbf{w})\|_2^2,$$

移项正是式 (4.15)。这个推导使用全局强凸下界；只有局部 Hessian 正定时，不能直接得到全域 PL 条件。反过来，PL 函数可以有多个最小点。

PL 条件也确实可以出现在非凸函数中。考虑

$$f(x, y) = x^2 + 2 \sin^2 x.$$

它与 y 无关，因而最小点不唯一。其一阶导数为 $\partial f / \partial x = 2(x + \sin 2x)$ ；当 $x > 0$ 时，若 $x \leq 1$ 则两项均非负，若 $x > 1$ 则 $x + \sin 2x \geq x - 1 > 0$ ，负半轴由奇对称性处理，所以导数只在 $x = 0$ 时为零。比值

$$R(x) = \frac{\|\nabla f(x, y)\|_2^2}{2f(x, y)}$$

在 $x \neq 0$ 时为正, 并且 $x \rightarrow 0$ 时趋于 6, $|x| \rightarrow \infty$ 时趋于 2。把两端之外的剩余区域限制为紧集, 连续函数 R 在其中有正下界, 故某个 $\mu > 0$ 使式 (4.15) 成立。另一方面, $\partial^2 f / \partial x^2 = 2 + 4 \cos 2x$ 在某些点为负, 所以 f 并不凸; 该二阶导数下界为 -2 、绝对值上界为 6, 所以它仍是 6 光滑的。负曲率下界的另一用途将在邻近方法中解释; 这里的例子表明非凸性本身不排斥目标值的梯度控制。

若满足 PL 条件, 把式 (4.15) 代入式 (4.12), 在 $\eta = 1/L$ 时得到

$$f(\mathbf{w}^{(t)}) - f^* \leq \left(1 - \frac{\mu}{L}\right)^t (f(\mathbf{w}^{(0)}) - f^*). \quad (4.16)$$

强凸函数满足 PL 条件, 还由 $f(\mathbf{w}) - f^* \geq \mu \|\mathbf{w} - \mathbf{w}^*\|_2^2 / 2$ 把目标误差转成参数误差。没有强凸时, 式 (4.16) 不保证迭代趋向某个唯一参数。

固定步长需要已知或估计 L 。回溯线搜索从候选步长开始缩小, 直到 $f(\mathbf{w} - \eta \nabla f(\mathbf{w})) \leq f(\mathbf{w}) - c\eta \|\nabla f(\mathbf{w})\|_2^2$ 成立, 其中 $c \in (0, 1)$ 。线搜索在当前点检查候选是否充分下降; 学习率调度则规定每轮采用的 $\eta^{(t)}$, 可以预先设定, 也可以随训练进度变化。二者都不能弥补错误梯度或无下界目标。

具体执行回溯时, 给定初始试探步长 $\bar{\eta} > 0$ 、缩减比例 $\gamma \in (0, 1)$ 与 $c \in (0, 1)$ 。每轮先算一次 $\mathbf{g} = \nabla f(\mathbf{w})$, 若 $\|\mathbf{g}\|_2$ 已满足停止要求就返回; 否则从 $\eta = \bar{\eta}$ 开始, 计算候选 $\mathbf{w} - \eta \mathbf{g}$ 的函数值, 若未满足上述充分下降条件, 令 $\eta \leftarrow \gamma \eta$ 再试, 接受后进入下一轮。下降引理保证 $\eta \leq 2(1-c)/L$ 时一定通过, 所以全局 L 光滑时每轮有限次结束, 接受步长至少为 $\min\{\bar{\eta}, 2\gamma(1-c)/L\}$ 。增加的成本主要是试探点函数求值, 而非每次重算当前位置的梯度。

在式 (4.3) 中, $\eta = 1/16$ 给 $\mathbf{w}^{(t)} = (2(15/16)^t, 0)^\top$ ($t \geq 1$), 于是 $f(\mathbf{w}^{(t)}) = 2(15/16)^{2t}$ 。第二坐标一步消去, 第一坐标却受较大曲率限制而缓慢缩小。 $\eta = 0.1$ 使两坐标分别乘 0.9 与 -0.6 , 目标仍下降但路径振荡; $\eta = 1/8$ 使第二坐标等幅振荡, $\eta > 1/8$ 使它发散。一般非凸问题返回梯度范数最小的已访问点, 式 (4.13) 控制其驻点残差; 凸问题可返回最后一点并用式 (4.14) 控制目标差。已知 PL 常数时, $\|\nabla f\|_2 \leq \sqrt{2\mu\epsilon}$ 足以保证目标差不超过 ϵ ; 不能将这条停止规则无条件用于所有光滑目标。

4.2.1.2 动量与加速

先用二次目标检查统一步长为何会走得慢。对 $f(\mathbf{w}) = \frac{1}{2} \mathbf{w}^\top \mathbf{H} \mathbf{w} - \mathbf{c}^\top \mathbf{w}$, 令 $\mathbf{e}^{(t)}$ 为当前参数与最小点的差, 梯度下降的误差满足 $\mathbf{e}^{(t+1)} = (\mathbf{I} - \eta \mathbf{H}) \mathbf{e}^{(t)}$ 。当 $\mathbf{H} > \mathbf{0}$ 但条件数 $\kappa = L/\mu$ 很大时, 同一步长必须同时照顾陡峭与平坦方向, 平坦方向因而收敛缓慢。

动量法 (momentum method) 保存过去方向, 使连续几步指向同一侧的梯度能够累积。这里采用重球 (heavy-ball) 形式:

$$\mathbf{v}^{(t+1)} = \beta \mathbf{v}^{(t)} + \nabla f(\mathbf{w}^{(t)}), \quad \mathbf{w}^{(t+1)} = \mathbf{w}^{(t)} - \eta \mathbf{v}^{(t+1)}.$$

加入历史方向后, 下一轮误差同时取决于本轮和上一轮误差。这样可以加快平坦方向的移动, 也可能使陡峭方向持续越过低点, 因此 β 和 η 必须配合选择。取 $\mathbf{v}^{(0)} = 0$, 或等价地令 $\mathbf{w}^{(-1)} = \mathbf{w}^{(0)}$, 即可启动重球迭代。每轮只需一次当前位置梯度、一个历史方向和向量加法; 它没有计算 Hessian。对上述正定二次目标, 曲率为 λ_i 的特征方向满足

$$e_i^{(t+1)} = (1 + \beta - \eta \lambda_i) e_i^{(t)} - \beta e_i^{(t-1)}.$$

该方向的两个特征根都严格位于单位圆内, 当且仅当 $-1 < \beta < 1$ 且 $0 < \eta \lambda_i < 2(1 + \beta)$ 。因而常用的 $0 \leq \beta < 1$ 还须配合 $0 < \eta < 2(1 + \beta)/L$, 才能保证所有方向稳定。若已知 $0 < \mu \leq \lambda_i \leq L$, 经典重球参数

$$\eta = \frac{4}{(\sqrt{L} + \sqrt{\mu})^2}, \quad \beta = \left(\frac{\sqrt{L} - \sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}} \right)^2$$

给出这一二次模型上的代表性最坏方向速率; 它不是一般非凸目标或含噪梯度下的无条件调参规则。稳定区间也可从特征多项式 $r^2 - (1 + \beta - \eta \lambda_i)r + \beta$ 核对: 实系数二次多项式的两根在单位圆内, 等价于 $|\beta| < 1$ 、 $\eta \lambda_i > 0$ 与 $2 + 2\beta - \eta \lambda_i > 0$ 。经典参数的根模至多 $q = (\sqrt{L} - \sqrt{\mu})/(\sqrt{L} + \sqrt{\mu})$, 端点的重根会带来 tq^t 因子; 因此不能不带常数地把有限步参数误差写成 q^t 。在共同二次例上, $\eta = 4/25$ 、 $\beta = 9/25$ 且零初速度给出精确轨迹

$$w_1^{(t)} = (2 + 0.8t)0.6^t, \quad w_2^{(t)} = (2 + 3.2t)(-0.6)^t.$$

第一步为 (1.68, -3.12), 目标从 34 升至 79.2864, 之后仍趋于零。重球的稳定和渐近提速不等于逐步下降; 给定有限预算时要连同启动阶段比较。

历史位移还可以用来预测下一步将到达哪里, 再在这个预测位置计算梯度, 修正移动方向。Nesterov 加速梯度 (Nesterov accelerated gradient) 采用这种做法; 下式中的 $\mathbf{z}^{(t)}$ 就是由历史位移得到的前瞻点:

$$\begin{aligned} \mathbf{w}^{(t+1)} &= \mathbf{z}^{(t)} - \frac{1}{L} \nabla f(\mathbf{z}^{(t)}), \quad q^{(t+1)} = \frac{1 + \sqrt{1 + 4(q^{(t)})^2}}{2}, \\ \mathbf{z}^{(t+1)} &= \mathbf{w}^{(t+1)} + \frac{q^{(t)} - 1}{q^{(t+1)}} (\mathbf{w}^{(t+1)} - \mathbf{w}^{(t)}). \end{aligned}$$

初始化为 $\mathbf{z}^{(0)} = \mathbf{w}^{(0)}$ 、 $q^{(0)} = 1$ 。必须先得到新点，再形成下一轮前瞻点；不能把下一轮外推系数提前用于本轮。若 f 为凸可微函数、梯度 L -Lipschitz 连续、最小点存在，并且每步使用精确梯度和步长 $1/L$ ，则对 $T \geq 1$,

$$f(\mathbf{w}^{(T)}) - f^* \leq \frac{2L\|\mathbf{w}^{(0)} - \mathbf{w}^*\|_2^2}{(T+1)^2}. \quad (4.17)$$

同样条件下，普通梯度下降的一般保证为 $O(1/T)$ 。强凸时可以另取固定外推系数 $\beta = (\sqrt{L} - \sqrt{\mu})/(\sqrt{L} + \sqrt{\mu})$ 与步长 $1/L$ ，获得 $O((1 - \sqrt{\mu/L})^T)$ 的目标误差界；这不是重球的步长参数。在一维二次函数 $f(w) = \lambda w^2/2$ 上，上述一般凸加速迭代可直接核验为

$$\mathbf{w}^{(t+1)} = \left(1 - \frac{\lambda}{L}\right) \left((1 + \beta^{(t)})\mathbf{w}^{(t)} - \beta^{(t)}\mathbf{w}^{(t-1)}\right).$$

其中 $t \geq 1$ 时 $\beta^{(t)} = (q^{(t-1)} - 1)/q^{(t)}$ ，初始化时取 $\beta^{(0)} = 0$ 。当 $\lambda = L$ 时一步到达零点；当 $\lambda \ll L$ 时，跨步项改变平坦方向上的二阶递推，但系数选错仍会振荡。为证明一般凸目标也满足上述有限步误差界，需要同时跟踪目标差和参数距离，使它们在逐轮相加时相消。下面构造这样的组合量。对 $\mathbf{x}^+ = \mathbf{z} - \nabla f(\mathbf{z})/L$ ，光滑上界和凸一阶下界合并为

$$f(\mathbf{x}^+) - f(\mathbf{v}) \leq \frac{L}{2} (\|\mathbf{v} - \mathbf{z}\|_2^2 - \|\mathbf{v} - \mathbf{x}^+\|_2^2).$$

取 $\mathbf{v} = (1 - 1/q^{(t)})\mathbf{w}^{(t)} + \mathbf{w}^*/q^{(t)}$ ，再用凸性控制 $f(\mathbf{v})$ 。记 $\Delta^{(t)} = f(\mathbf{w}^{(t)}) - f^*$ 、 $\mathbf{u}^{(t+1)} = q^{(t)}\mathbf{w}^{(t+1)} - (q^{(t)} - 1)\mathbf{w}^{(t)}$ 及 $\mathbf{u}^{(0)} = \mathbf{w}^{(0)}$ ，乘以 $(q^{(t)})^2$ 后得到

$$(q^{(t)})^2 \Delta^{(t+1)} + \frac{L}{2} \|\mathbf{u}^{(t+1)} - \mathbf{w}^*\|_2^2 \leq q^{(t)}(q^{(t)} - 1)\Delta^{(t)} + \frac{L}{2} \|\mathbf{u}^{(t)} - \mathbf{w}^*\|_2^2.$$

这里用了 $q^{(t)}\mathbf{z}^{(t)} - (q^{(t)} - 1)\mathbf{w}^{(t)} = \mathbf{u}^{(t)}$ 。 $t = 0$ 时目标系数为零， $t \geq 1$ 时 $q^{(t)}(q^{(t)} - 1) = (q^{(t-1)})^2$ ，故逐次相消后有 $(q^{(T-1)})^2 \Delta^{(T)} \leq L\|\mathbf{w}^{(0)} - \mathbf{w}^*\|_2^2/2$ 。递推又给 $q^{(T-1)} \geq (T+1)/2$ ，即得式 (4.17)。每轮代价仍是一次梯度与几个向量操作，但目标未必单调；一般凸情形的目标收敛也没有规定唯一参数。强凸时才可再用式 (4.9) 转成参数界。

4.2.2 二阶方法

只控制梯度的最大变化会让平坦方向也受陡峭方向的步长约束。二阶方法直接在局部模型中保留各方向曲率；收益取决于曲率模型是否可靠，以及取得矩阵、求解线性方程的成本是否能够接受。

4.2.2.1 牛顿与 Gauss-Newton 方法

梯度下降只按同一尺度限制移动幅度。如果能估计每个方向的曲率，就可以让平坦方向走得远一些、陡峭方向走得近一些。牛顿法 (Newton's method) 为此在 $\mathbf{w}^{(t)}$ 处保留二阶展开，建立关于增量 $\mathbf{p}$ 的局部二次模型

$$m^{(t)}(\mathbf{p}) = f(\mathbf{w}^{(t)}) + \langle \nabla f(\mathbf{w}^{(t)}), \mathbf{p} \rangle + \frac{1}{2} \mathbf{p}^\top \nabla^2 f(\mathbf{w}^{(t)}) \mathbf{p}.$$

令 $\nabla_{\mathbf{p}} m^{(t)}(\mathbf{p}^{(t)}) = \mathbf{0}$ ，便得到牛顿方程

$$\nabla^2 f(\mathbf{w}^{(t)}) \mathbf{p}^{(t)} = -\nabla f(\mathbf{w}^{(t)}), \quad \mathbf{w}^{(t+1)} = \mathbf{w}^{(t)} + \alpha^{(t)} \mathbf{p}^{(t)}.$$

若 Hessian 矩阵在最优点附近正定且 Lipschitz 连续，取单位步长可得到局部二次收敛。但 Hessian 矩阵不定时，牛顿方向未必下降；离最优点较远时还需线搜索或信赖域。可逆性只使方程有唯一解，正定性才使这个解成为二次模型的最小点。实际过程是计算梯度与 Hessian，求解线性方程得到 $\mathbf{p}^{(t)}$ ，核验其下降性，再选择步长。若 Hessian 不正定，可用 $\nabla^2 f + \delta^{(t)} \mathbf{I} > 0$ 替代它；沿该方向执行充分下降线搜索，而不是直接接受单位步长。奇异 Hessian 下也不能照写逆矩阵。

局部二次速率有可量化的范围。设 $\nabla f(\mathbf{w}^*) = 0$ ，在包含 $\mathbf{w}^*$ 的球内 $\nabla^2 f(\mathbf{w}) \geq m\mathbf{I}$ 且 Hessian 为 M -Lipschitz，其中 $m > 0$ 。对单位牛顿步，令 $\mathbf{e} = \mathbf{w} - \mathbf{w}^*$ ，沿线段积分梯度得

$$\mathbf{e}^+ = \nabla^2 f(\mathbf{w})^{-1} \int_0^1 (\nabla^2 f(\mathbf{w}) - \nabla^2 f(\mathbf{w}^* + s\mathbf{e})) \mathbf{e} ds, \quad \|\mathbf{e}^+\|_2 \leq \frac{M}{2m} \|\mathbf{e}\|_2^2.$$

初始误差足够小，使这个界将点留在同一球内，才可逐轮使用。共同二次例的 Hessian 恒定， $M = 0$ ，求解 $\mathbf{H}\mathbf{p} = -\mathbf{H}\mathbf{w}$ 得到 $\mathbf{p} = -\mathbf{w}$ ，一步到达零点。一般稠密 d 维问题需要存储 $O(d^2)$ 个矩阵元素，直接分解约需 $O(d^3)$ 运算；本例的对角结构才把这一成本降为 $O(d)$ 。

对非线性最小二乘 $f(\mathbf{w}) = \frac{1}{2} \|\mathbf{r}(\mathbf{w})\|_2^2$ ，设 $\mathbf{r} : \mathbb{R}^d \rightarrow \mathbb{R}^m$ ，其中 $r_i(\mathbf{w})$ 记录第 i 项预测与观测之间的差。记残差向量的 Jacobian 矩阵为 $\mathbf{J}(\mathbf{w}) \in \mathbb{R}^{m \times d}$ ，其第 i 行为 $\mathbf{J}_{i,:}(\mathbf{w}) = \nabla r_i(\mathbf{w})^\top$ ，则

$$\nabla^2 f(\mathbf{w}) = \mathbf{J}(\mathbf{w})^\top \mathbf{J}(\mathbf{w}) + \sum_{i=1}^m r_i(\mathbf{w}) \nabla^2 r_i(\mathbf{w}).$$

完整 Hessian 还要计算每个残差的二阶导数。若残差很小，或残差函数在附近近似线性，上式第二项可能很小；这时只保留第一项就能减少计算。Gauss-Newton 法采用这个近似，使用半正定矩阵 $\mathbf{J}^\top \mathbf{J}$ 。残差大时，省略项

可能决定曲率，不能默认它可忽略。它的方向不是凭空替换矩阵，而是先线性化残差，求解

$$\min_{\mathbf{p}} \frac{1}{2} \|\mathbf{r}(\mathbf{w}) + \mathbf{J}(\mathbf{w})\mathbf{p}\|_2^2, \quad \mathbf{J}^\top \mathbf{J} \mathbf{p} = -\mathbf{J}^\top \mathbf{r}.$$

残差 Jacobian 描述每个残差对参数的变化，Hessian 描述整个标量目标的曲率，两者维度也不同。 $\mathbf{J}$ 满列秩时子问题方向唯一；秩亏时可用 QR 或奇异值分解取最小范数方向，也可增加 $\delta \|\mathbf{p}\|_2^2/2$ 得到 $(\mathbf{J}^\top \mathbf{J} + \delta \mathbf{I})\mathbf{p} = -\mathbf{J}^\top \mathbf{r}$ 。对未正则化子问题，直接形成正规方程会平方条件数，数值实现常直接解线性最小二乘。

若解附近 $\mathbf{J}$ 满列秩且 Lipschitz、残差在解处为零，则 $\mathbf{r}(\mathbf{w}) = \mathbf{J}(\mathbf{w})(\mathbf{w} - \mathbf{w}^*) + O(\|\mathbf{w} - \mathbf{w}^*\|_2^2)$ ，左逆一致有界便给出局部二次误差。非零残差时，进一步设各残差二阶连续可微，记 $\mathbf{E}^* = \sum_i r_i(\mathbf{w}^*) \nabla^2 r_i(\mathbf{w}^*)$ ；Gauss-Newton 映射在驻点处的导数为 $-(\mathbf{J}^{*\top} \mathbf{J}^*)^{-1} \mathbf{E}^*$ 。若在某个一致矩阵范数下，这个导数矩阵的范数小于 1，附近的误差就会在每一步缩小，从而得到局部收缩；这通常只给线性速率。残差大或秩条件失效时不能保证收敛。共同二次例可取 $\mathbf{r}(\mathbf{w}) = (w_1, 4w_2)^\top$ ，残差本身线性，Gauss-Newton 与牛顿方向完全一致。

4.2.2.2 拟牛顿方法

完整 Hessian 可能难以获得，但走过一步后，已经知道位移与梯度变化。拟牛顿法 (quasi-Newton method) 用这两份信息修正曲率模型，不显式计算 Hessian 矩阵。它记录梯度差 $\mathbf{y}^{(t)} = \nabla f(\mathbf{w}^{(t+1)}) - \nabla f(\mathbf{w}^{(t)})$ 与位移 $\mathbf{s}^{(t)} = \mathbf{w}^{(t+1)} - \mathbf{w}^{(t)}$ 。新的曲率矩阵应能解释这次观测：用它乘以位移，应得到相应的梯度变化。这就是割线条件 $\mathbf{B}^{(t+1)} \mathbf{s}^{(t)} = \mathbf{y}^{(t)}$ 。若 $\mathbf{B}^{(t)}$ 近似 Hessian 矩阵，BFGS 更新为

$$\mathbf{B}^{(t+1)} = \mathbf{B}^{(t)} + \frac{\mathbf{y}^{(t)}(\mathbf{y}^{(t)})^\top}{(\mathbf{y}^{(t)})^\top \mathbf{s}^{(t)}} - \frac{\mathbf{B}^{(t)} \mathbf{s}^{(t)}(\mathbf{s}^{(t)})^\top \mathbf{B}^{(t)}}{(\mathbf{s}^{(t)})^\top \mathbf{B}^{(t)} \mathbf{s}^{(t)}}. \quad (4.18)$$

当 $\mathbf{B}^{(t)} > \mathbf{0}$ 且曲率条件 $(\mathbf{y}^{(t)})^\top \mathbf{s}^{(t)} > 0$ 成立时，式 (4.18) 保持 $\mathbf{B}^{(t+1)} > \mathbf{0}$ ，相应搜索方向 $-(\mathbf{B}^{(t+1)})^{-1} \nabla f$ 才由正定性保证是下降方向。沿下降方向执行满足 Wolfe 条件的线搜索可产生该正曲率内积。具体地，令 $\mathbf{w}^{(t+1)} = \mathbf{w}^{(t)} + \alpha^{(t)} \mathbf{p}^{(t)}$ ，其中 $\nabla f(\mathbf{w}^{(t)})^\top \mathbf{p}^{(t)} < 0$ 。Wolfe 条件要求存在 $0 < c_1 < c_2 < 1$ 使

$$\begin{aligned} f(\mathbf{w}^{(t+1)}) &\leq f(\mathbf{w}^{(t)}) + c_1 \alpha^{(t)} \nabla f(\mathbf{w}^{(t)})^\top \mathbf{p}^{(t)}, \\ \nabla f(\mathbf{w}^{(t+1)})^\top \mathbf{p}^{(t)} &\geq c_2 \nabla f(\mathbf{w}^{(t)})^\top \mathbf{p}^{(t)}. \end{aligned} \quad (4.19)$$

第一行要求本次移动产生足够的目标下降；第二行要求新点的方向导数不再像原来那样负，从而避免接受过小、几乎没有前进的步长。第二行称为Wolfe 曲率条件（Wolfe curvature condition）。由 $\mathbf{s}^{(t)} = \alpha^{(t)} \mathbf{p}^{(t)}$ 可得

$$(\mathbf{y}^{(t)})^\top \mathbf{s}^{(t)} \geq \alpha^{(t)}(c_2 - 1) \nabla f(\mathbf{w}^{(t)})^\top \mathbf{p}^{(t)} > 0.$$

非凸或梯度含噪时，上述条件可能难以满足，此时可能需要阻尼或跳过更新。

正定性的理由值得单独核验。省略轮次上标，对任意 $\mathbf{v} \neq 0$,

$$\mathbf{v}^\top \mathbf{B}^+ \mathbf{v} = \mathbf{v}^\top \mathbf{B} \mathbf{v} - \frac{(\mathbf{v}^\top \mathbf{B} \mathbf{s})^2}{\mathbf{s}^\top \mathbf{B} \mathbf{s}} + \frac{(\mathbf{v}^\top \mathbf{y})^2}{\mathbf{y}^\top \mathbf{s}}.$$

前两项由 $\mathbf{B}$ 内积的 Cauchy-Schwarz 不等式非负，仅在 $\mathbf{v}$ 与 $\mathbf{s}$ 平行时为零；此时 $\mathbf{y}^\top \mathbf{s} > 0$ 又使最后一项严格为正。把更新式乘 $\mathbf{s}$ ，还可直接检查 $\mathbf{B}^+ \mathbf{s} = \mathbf{y}$ 。割线条件只匹配一个观测方向，不等于已经恢复全部曲率。

一次 BFGS 迭代从正定 $\mathbf{B}^{(t)}$ 出发，解 $\mathbf{B}^{(t)} \mathbf{p}^{(t)} = -\nabla f(\mathbf{w}^{(t)})$ ，进行 Wolfe 线搜索，计算新梯度与 $(\mathbf{s}^{(t)}, \mathbf{y}^{(t)})$ 后再更新矩阵。只检查充分下降、不断缩短步长的 Armijo 回溯未必满足 Wolfe 第二式，因为步长太小会使方向导数几乎不变；通常先寻找包含合适步长的区间，再在区间内继续试探。若观测曲率太小，给定 $\delta \in (0, 1)$ ，可以令

$$\tilde{\mathbf{y}} = \theta \mathbf{y} + (1 - \theta) \mathbf{B} \mathbf{s}, \quad \theta = \begin{cases} 1, & \mathbf{s}^\top \mathbf{y} \geq \delta \mathbf{s}^\top \mathbf{B} \mathbf{s}, \\ \frac{(1 - \delta) \mathbf{s}^\top \mathbf{B} \mathbf{s}}{\mathbf{s}^\top \mathbf{B} \mathbf{s} - \mathbf{s}^\top \mathbf{y}}, & \text{其余情形.} \end{cases}$$

用 $\tilde{\mathbf{y}}$ 替代 $\mathbf{y}$ 便有 $\mathbf{s}^\top \tilde{\mathbf{y}} \geq \delta \mathbf{s}^\top \mathbf{B} \mathbf{s} > 0$ ；代价是割线条件改为匹配修正后的曲率。零位移或不可靠梯度差应跳过更新。

为避免每轮重新分解稠密矩阵，通常维护 $\mathbf{C} = \mathbf{B}^{-1}$ 并用等价公式

$$\mathbf{C}^+ = (\mathbf{I} - \rho \mathbf{s} \mathbf{y}^\top) \mathbf{C} (\mathbf{I} - \rho \mathbf{y} \mathbf{s}^\top) + \rho \mathbf{s} \mathbf{s}^\top, \quad \rho = (\mathbf{y}^\top \mathbf{s})^{-1}.$$

方向是 $-\mathbf{C} \nabla f$ ，更新与乘法各需 $O(d^2)$ 运算和存储；有限记忆版本只保存最近 m 对位移、梯度差，以 $O(md)$ 代价应用近似逆。共同二次例取 $\mathbf{B}^{(0)} = \mathbf{I}$ ，第一方向为 $(-2, -32)$ ，精确线搜索步长为 $257/4097$ ；第一步并不像牛顿步直达最小点，所得 $\mathbf{y} = \mathbf{H} \mathbf{s}$ 才提供沿这次位移的曲率信息。精确算术与精确线搜索下，正定二次目标的 BFGS 至多 d 步终止；一般光滑目标的局部超线性结论另需强凸邻域、连续曲率与合适线搜索，不能从保持正定性直接推出。这里比较的是到局部解的参数误差 $e_t = \|\mathbf{w}^{(t)} - \mathbf{w}^*\|_2$ 。在未有限步终止且 $e_t \rightarrow 0$ 的情形，超线性收敛（superlinear convergence）指 $e_{t+1}/e_t \rightarrow 0$ ，即每一步相对上一步的误差比例也趋于零。此前牛顿法的二

次收敛还给出近解处 $\mathbf{e}_{t+1} \leq C\mathbf{e}_t^2$ 的更具体上界，因此二次收敛蕴含超线性收敛，反向却不必成立。

共同二次例中，第二坐标的曲率是第一坐标的 16 倍：统一步长若照顾第二方向，第一方向就走得慢。能否分别调整各方向的移动尺度，使它们更同步地接近解？预条件（preconditioning）解决的是这个尺度问题。最简单的形式选择正定矩阵 $\mathbf{P}$ ，按

$$\mathbf{w}^{(t+1)} = \mathbf{w}^{(t)} - \eta \mathbf{P} \nabla f(\mathbf{w}^{(t)})$$

更新。这等价于在新的坐标或内积下做最陡下降。若 $p_i > 0$ ，并且

$$\mathbf{P} = \mathbf{Q} \text{diag}(p_1, \dots, p_d) \mathbf{Q}^\top,$$

则定义

$$\mathbf{P}^{1/2} = \mathbf{Q} \text{diag}(\sqrt{p_1}, \dots, \sqrt{p_d}) \mathbf{Q}^\top.$$

这就是 $\mathbf{P}$ 唯一的对称正定平方根：它满足 $\mathbf{P}^{1/2} \mathbf{P}^{1/2} = \mathbf{P}$ ，并且可逆，其逆记为 $\mathbf{P}^{-1/2}$ 。对当前正定二次目标，记

$$\tilde{\mathbf{H}} = \mathbf{P}^{1/2} \mathbf{H} \mathbf{P}^{1/2}, \quad 0 < \tilde{\mu} = \lambda_{\min}(\tilde{\mathbf{H}}) \leq \lambda_{\max}(\tilde{\mathbf{H}}) = \tilde{L}.$$

原坐标中的误差递推为 $\mathbf{e}^{(t+1)} = (\mathbf{I} - \eta \mathbf{P} \mathbf{H}) \mathbf{e}^{(t)}$ 。令 $\tilde{\mathbf{e}}^{(t)} = \mathbf{P}^{-1/2} \mathbf{e}^{(t)}$ ，则

$$\tilde{\mathbf{e}}^{(t+1)} = (\mathbf{I} - \eta \tilde{\mathbf{H}}) \tilde{\mathbf{e}}^{(t)}, \quad \mathbf{P}^{-1/2} (\mathbf{I} - \eta \mathbf{P} \mathbf{H}) \mathbf{P}^{1/2} = \mathbf{I} - \eta \tilde{\mathbf{H}}.$$

右侧矩阵由可逆坐标变换 $\mathbf{P}^{1/2}$ 得到，因而与原误差递推矩阵相似；相似矩阵具有相同特征值。由于 $\tilde{\mathbf{H}}$ 对称正定，迭代对任意初始误差收敛当且仅当 $0 < \eta < 2/\tilde{L}$ 。取 $\eta = 2/(\tilde{L} + \tilde{\mu})$ 时，在变换后的欧氏范数中，每步最坏收缩因子为

$$\frac{\tilde{\kappa} - 1}{\tilde{\kappa} + 1}, \quad \tilde{\kappa} = \frac{\tilde{L}}{\tilde{\mu}}.$$

因此预条件的目标不是单独让 $\mathbf{P}$ 的条件数小，而是让变换后曲率 $\tilde{\mathbf{H}}$ 的条件数接近 1。固定 $\mathbf{P} > \mathbf{0}$ 只保证定义了合法内积；若它与 $\mathbf{H}$ 不匹配， $\tilde{\kappa}$ 反而可能增大。对一般二阶可微的光滑强凸函数，需要在所有迭代经过的区域统一满足 $\tilde{\mu} \mathbf{I} \leq \mathbf{P}^{1/2} \nabla^2 f(\mathbf{w}) \mathbf{P}^{1/2} \leq \tilde{L} \mathbf{I}$ ，上述步长范围与线性收敛解释才相应延续；变化的预条件矩阵还需额外控制。

动量利用历史更新，牛顿类近似当前曲率，预条件改变几何尺度；三者可能组合，却不是同一种机制。第 6 章“线性空间”将从线性方程求解的角度比较预条件对搜索空间、残差和总成本的影响；Fisher 矩阵与经验梯度二阶矩的差别则需等概率对象建立后讨论。

示例 4.11 两个曲率方向上的预条件 取 $f(\mathbf{w}) = (w_1^2 + 16w_2^2)/2$, 初值 $(2, 2)^\top$ 。普通梯度下降若取 $\eta = 0.1$, 两个坐标分别乘以 0.9 与 -0.6 , 因而 $\mathbf{w}^{(t)} = (2 \times 0.9^t, 2 \times (-0.6)^t)^\top$ 。第二坐标来回越过谷底, 第一坐标却缓慢缩小。取 $\mathbf{P} = \text{diag}(1, 1/16)$ 及 $\eta = 1/2$ 后, $\mathbf{P}\nabla f(\mathbf{w}) = \mathbf{w}$, 两坐标每步都减半。




图 4.2 例 4.11 中的精确更新路径。灰线是同一二次目标的等值线, 蓝、红圆点分别表示普通更新与预条件更新, 黄色星号是最小点。预条件使用了已知曲率, 获得和应用这一矩阵的成本仍属于算法代价。

这个例子中的预条件恰好消除了两个方向的尺度差。一般目标的曲率会随位置变化, 近似矩阵也有误差; 因此图中的直达路径解释机制, 不构成所有预条件方法都更快的保证。从坐标 $\mathbf{w} = \mathbf{P}^{1/2}\mathbf{z}$ 看, 预条件只是改变测量方向长度的方式; 它也可以用于牛顿线性方程的迭代求解, 并不必然是 Hessian 的近似逆。在共同例中, 普通 $\eta = 1/16$ 梯度法需要 $T \geq \log(2/\varepsilon)/(2\log(16/15))$ (并至少一步) 达到目标差 ε ; 对角预条件 $\eta = 1/2$ 的目标为 344^{-T} ; 牛顿与 Gauss-Newton 各解一次对角系统即结束。前两者每步只做向量运算, 而一般稠密二阶方法的矩阵成本不能由这个特殊例子代表。停止时都应核验原目标或原坐标梯度残差, 而不能只看被任意缩小的预条件方向长度。矩阵分解、条件数与线性方程残差的具体关系可回查第 6 章。

4.3 无约束非光滑目标的求解

加入绝对值损失或 ℓ_1 惩罚后, 目标在零点有尖角, 普通梯度在这里没有定义。一种办法是寻找仍能给出全局线性下界的方向, 用次梯度代替梯度; 另一种办法是保留尖角项, 直接求解“原代价加上移动距离惩罚”的小问

题, 得到邻近更新。下面分别说明两种办法怎样处理不可微点。随机抽样带来的信息误差留到计算预算一节。

4.3.1 次梯度方法

绝对值损失和 ℓ_1 稀疏惩罚在零点不可微, 因而不能直接代入普通梯度更新。凸函数仍可用全局仿射下界描述: 允许同一点有多个支撑斜率, 就能保留用于比较目标值的方向信息。

定义 4.12 凸次梯度与次微分 设 $f: \mathbb{R}^d \rightarrow \mathbb{R} \cup \{+\infty\}$ 为适当凸函数, $f(\mathbf{u})$ 有限。向量 $\mathbf{g} \in \mathbb{R}^d$ 若满足

$$f(\mathbf{v}) \geq f(\mathbf{u}) + \langle \mathbf{g}, \mathbf{v} - \mathbf{u} \rangle \quad \text{对所有 } \mathbf{v},$$

就称为 f 在 $\mathbf{u}$ 处的次梯度 (subgradient)。全部次梯度组成 $\partial f(\mathbf{u})$, 称为次微分; 它可以是空集。

例如

$$\partial|x| = \begin{cases} \{1\}, & x > 0, \\ [-1, 1], & x = 0, \\ \{-1\}, & x < 0. \end{cases}$$

凸函数在 $\mathbf{w}^*$ 处最优, 当且仅当 $\mathbf{0} \in \partial f(\mathbf{w}^*)$ 。若零向量是次梯度, 定义立即给出 $f(\mathbf{v}) \geq f(\mathbf{w}^*)$; 反过来, 若 $\mathbf{w}^*$ 全局最优, 则 $f(\mathbf{v}) \geq f(\mathbf{w}^*) + \langle \mathbf{0}, \mathbf{v} - \mathbf{w}^* \rangle$, 所以零向量满足次梯度定义。这个等价性依赖凸次梯度采用全局下界定义。若要把 $f + r$ 的次微分直接写成 $\partial f + \partial r$, 或把约束写成指标函数后拆分次微分, 还需核验额外的定义域条件, 涉及两个函数在哪些点同时取有限值、在这些点附近是否连续。两个函数都凸, 并不足以无条件使用这个等式。本节不依赖这条求和规则, 而直接用次梯度定义中的全局下界推导所需的最优性关系。

次梯度迭代选 $\mathbf{g}^{(t)} \in \partial f(\mathbf{w}^{(t)})$ 并令 $\mathbf{w}^{(t+1)} = \mathbf{w}^{(t)} - \eta^{(t)} \mathbf{g}^{(t)}$ 。支撑斜率提供下界, 却未必是实际下降方向。例如 $f(x) = |x|$, 在 $x = 0.2$ 取 $\eta = 1$, 更新到 -0.8 后目标反而增大, 这一次是步长过大的结果。尖点还可能让任意小步都不能下降: 对 $f(x, y) = |x| + y/2$, 在 $(0, 0)$ 可取次梯度 $(1, 1/2)$, 沿其负方向移动 $t > 0$ 后目标为 $3t/4 > 0$ 。所以不能给次梯度更新强加光滑梯度的逐步下降要求。实际输出可取已访问点中目标最小者, 或取步长加权平均 $\bar{\mathbf{w}}^{(T)} = \sum_{t < T} \eta^{(t)} \mathbf{w}^{(t)} / \sum_{t < T} \eta^{(t)}$ 。

设 f 凸、最小点 $\mathbf{w}^*$ 存在, 沿迭代能取得 $\|\mathbf{g}^{(t)}\|_2 \leq G$, 且 $\|\mathbf{w}^{(0)} - \mathbf{w}^*\|_2 \leq R$ 。展开距离并用次梯度下界得

$$\|\mathbf{w}^{(t+1)} - \mathbf{w}^*\|_2^2 \leq \|\mathbf{w}^{(t)} - \mathbf{w}^*\|_2^2 - 2\eta^{(t)}(f(\mathbf{w}^{(t)}) - f^*) + (\eta^{(t)})^2 G^2.$$

求和消去中间距离，再对平均点用 Jensen 不等式，得到

$$\begin{aligned} \min_{t < T} (f(\mathbf{w}^{(t)}) - f^*) &\leq \frac{\sum_{t < T} \eta^{(t)} (f(\mathbf{w}^{(t)}) - f^*)}{\sum_{t < T} \eta^{(t)}}, \\ f(\bar{\mathbf{w}}^{(T)}) - f^* &\leq \frac{R^2 + G^2 \sum_{t < T} (\eta^{(t)})^2}{2 \sum_{t < T} \eta^{(t)}}. \end{aligned} \quad (4.20)$$

同一右端也控制最佳候选。已知预算 T 且 $R, G > 0$ 时，固定 $\eta^{(t)} = R/(G\sqrt{T})$ 给出 $RG/\sqrt{T}$ ；不知道预算时可用递减步长，按实际的两个步长和评价误差。边界上次微分可能为空，强凸二次目标在全空间的次梯度也未必有界；上界 G 必须由目标或迭代区域另行保证，不能省略。

本节的凸次梯度也不同于第 3 章介绍的 Clarke 广义梯度。前者用一个全局仿射下界定义，直接产生凸最优性条件；后者取局部 Lipschitz 函数邻近可微点梯度极限的闭凸包，允许非凸局部结构。人为指定的替代梯度更只是反向计算信号，未必属于前面任一集合。三者名称相近，定义对象与可用结论并不相同。

4.3.2 邻近方法

次梯度法允许单步目标上升。另一条路线是每轮完整保留难处理的目标项，在“目标小”和“离当前点近”之间解一个折中子问题。

定义 4.13 凸函数的邻近算子 设 $r: \mathbb{R}^d \rightarrow \mathbb{R} \cup \{+\infty\}$ 适当、下半连续且凸， $\eta > 0$ 。函数 r 的邻近算子 (proximal operator) 定义为

$$\text{prox}_{\eta r}(\mathbf{z}) = \arg \min_{\mathbf{w}} \left\{ r(\mathbf{w}) + \frac{1}{2\eta} \|\mathbf{w} - \mathbf{z}\|_2^2 \right\}.$$

这里的 η 调节原代价 r 与距离惩罚的相对权重。 η 越小，偏离中心 $\mathbf{z}$ 同样远的代价越大，输出就越倾向于留在中心附近。二次项使目标强凸。存在性还需要防止 r 下降得太快，抵消二次距离；下面直接由凸性和下半连续性证明。后文将“适当、下半连续且凸”简称为“适当闭凸”，这里的“闭”是下半连续性的惯常表述，不要求有效定义域本身是闭集；对偶部分将再解释这种叫法的几何含义。

邻近子问题存在与唯一。取 $\mathbf{u} \in \text{dom } r$ 。下半连续且不取 $-\infty$ 的 r 在紧球 $\{\mathbf{v}: \|\mathbf{v} - \mathbf{u}\|_2 \leq 1\}$ 上有有限下界 m 。否则可取球内 $r(\mathbf{v}^{(k)}) \rightarrow -\infty$ 的序列，再取收敛子列，由下半连续性迫使极限点取 $-\infty$ 。对 $\mathbf{w} \in \text{dom } r$ 且 $R = \|\mathbf{w} - \mathbf{u}\|_2 > 1$ ，点 $\mathbf{v} = \mathbf{u} + (\mathbf{w} - \mathbf{u})/R$ 在该球上，凸性给

$$m \leq r(\mathbf{v}) \leq (1 - 1/R)r(\mathbf{u}) + r(\mathbf{w})/R, \quad r(\mathbf{w}) \geq r(\mathbf{u}) + R(m - r(\mathbf{u})).$$

所以当 $\mathbf{w}$ 离 $\mathbf{u}$ 很远时, $r(\mathbf{w})$ 的下降幅度至多与距离成线性比例; 对固定 $\mathbf{z}$, $\|\mathbf{w} - \mathbf{z}\|_2^2/(2\eta)$ 支配这一线性项。邻近目标强制、下半连续且适当, 由存在性小节达到最小值。其 $1/\eta$ 强凸性又排除两个不同最小点, 因而每个 $\mathbf{z}$ 都有唯一输出。 ■

还可以直接取得最优性关系而不用次微分求和规则。令 $\mathbf{p}$ 为邻近最小点, 比较它与 $\mathbf{p} + t(\mathbf{v} - \mathbf{p})$, 用 r 的凸性上界并展开平方, 除以 t 再令 $t \downarrow 0$, 得

$$r(\mathbf{v}) \geq r(\mathbf{p}) + \left\langle \frac{\mathbf{z} - \mathbf{p}}{\eta}, \mathbf{v} - \mathbf{p} \right\rangle.$$

故 $(\mathbf{z} - \mathbf{p})/\eta \in \partial r(\mathbf{p})$; 反向将该下界与平方距离相加又可证明最优。这个关系同时给出邻近解的核验条件。

定理 4.14 ℓ_1 邻近算子是软阈值 设 $\lambda \geq 0, \eta > 0$ 。对 $r(\mathbf{w}) = \lambda \|\mathbf{w}\|_1$,

$$[\text{prox}_{\eta r}(\mathbf{z})]_j = \text{sign}(z_j) \max\{|z_j| - \eta\lambda, 0\}.$$

证明. 目标按坐标可分, 只需最小化 $\lambda|w| + (w - z)^2/(2\eta)$ 。若 $w > 0$, 驻点为 $w = z - \eta\lambda$, 只在 $z > \eta\lambda$ 时落在该区域; 若 $w < 0$, 驻点为 $w = z + \eta\lambda$, 只在 $z < -\eta\lambda$ 时有效。若 $|z| \leq \eta\lambda$, 零点最优性条件 $0 \in \lambda[-1, 1] - z/\eta$ 成立, 所以 $w = 0$ 。合并三种情形即得结论。 ■

例如取 $\mathbf{z} = (3, 0.4, -2)^\top$ 与 $\eta\lambda = 1$, 软阈值输出 $(2, 0, -1)^\top$; 小幅坐标被直接置零。若改用 $r(\mathbf{w}) = \lambda \|\mathbf{w}\|_2^2/2$, 逐坐标驻点给出 $\text{prox}_{\eta r}(\mathbf{z}) = \mathbf{z}/(1 + \eta\lambda)$, 在同一参数下为 $(1.5, 0.2, -1)^\top$ 。两种正则化都缩小幅度, 只有前者在这个例子中产生精确零值。

邻近算子不会放大输入距离。令 $\mathbf{p} = \text{prox}_{\eta r}(\mathbf{x})$ 、 $\mathbf{q} = \text{prox}_{\eta r}(\mathbf{y})$ 。最优性条件给出 $(\mathbf{x} - \mathbf{p})/\eta \in \partial r(\mathbf{p})$ 和 $(\mathbf{y} - \mathbf{q})/\eta \in \partial r(\mathbf{q})$ 。把两个次梯度不等式相加, 得到

$$\langle \mathbf{x} - \mathbf{y}, \mathbf{p} - \mathbf{q} \rangle \geq \|\mathbf{p} - \mathbf{q}\|_2^2.$$

再用 Cauchy-Schwarz 不等式便有 $\|\mathbf{p} - \mathbf{q}\|_2 \leq \|\mathbf{x} - \mathbf{y}\|_2$ 。这个非扩张性质依赖凸次梯度的单调性; 非凸邻近子问题可能多解, 不能直接沿用。

若能直接求整个目标的邻近解, 邻近点方法令 $\mathbf{w}^{(t+1)} = \text{prox}_{\eta^{(t)} F}(\mathbf{w}^{(t)})$ 。与子问题候选 $\mathbf{w}^{(t)}$ 比较可得

$$F(\mathbf{w}^{(t+1)}) + \frac{\|\mathbf{w}^{(t+1)} - \mathbf{w}^{(t)}\|_2^2}{2\eta^{(t)}} \leq F(\mathbf{w}^{(t)}).$$

若 F 适当闭凸且有最小点, 邻近最优性关系与次梯度下界进一步给出

$$2\eta^{(t)}(F(\mathbf{w}^{(t+1)}) - F^*) \leq \|\mathbf{w}^{(t)} - \mathbf{w}^*\|_2^2 - \|\mathbf{w}^{(t+1)} - \mathbf{w}^*\|_2^2 - \|\mathbf{w}^{(t+1)} - \mathbf{w}^{(t)}\|_2^2.$$

固定 $\eta > 0$ 时, 求和并利用目标单调性得最后一点误差 $F(\mathbf{w}^{(T)}) - F^* \leq \|\mathbf{w}^{(0)} - \mathbf{w}^*\|_2^2 / (2\eta T)$ 。这里没有光滑步长限制, 但每一步可能要求解一个几乎同样困难的优化问题; 数学上唯一可解不等于计算上廉价。

整个 F 的邻近子问题若仍很难, 可以只近似其中容易求梯度的部分。对 $F = f + r$, 若 f 可微且 L 光滑、 r 适当闭凸, 近端梯度将 f 换成当前点的一阶近似, 同时完整保留 r :

$$\mathbf{w}^{(t+1)} = \text{prox}_{\eta r}(\mathbf{w}^{(t)} - \eta \nabla f(\mathbf{w}^{(t)})). \quad (4.21)$$

一次更新依次计算 ∇f 、形成邻近中心、求 r 的邻近解, 再评价原目标。例如共同二次目标加 $r(\mathbf{w}) = \lambda \|\mathbf{w}\|_1$ 时, 取 $\eta = 1/16$, 从 $(2, 2)$ 出发先到 $(15/8, 0)$, 随后软阈值得 $(\max\{15/8 - \lambda/16, 0\}, 0)$, 无需迭代求解邻近子问题。

令 $\mathbf{w}^+$ 为该更新、 $\mathbf{d} = \mathbf{w}^+ - \mathbf{w}$ 。邻近最优性给 $-\nabla f(\mathbf{w}) - \mathbf{d}/\eta \in \partial r(\mathbf{w}^+)$, 将次梯度不等式用于旧点, 再与 f 的光滑上界相加:

$$F(\mathbf{w}^+) \leq F(\mathbf{w}) - \left(\frac{1}{\eta} - \frac{L}{2}\right) \|\mathbf{d}\|_2^2. \quad (4.22)$$

故 $0 < \eta \leq 1/L$ 保证下降。由于带尖角的目标没有普通梯度, 需要用实际更新是否停止来检验驻点。为此定义可计算的近端梯度映射

$$\mathbf{G}_\eta(\mathbf{w}) = \frac{\mathbf{w} - \mathbf{w}^+}{\eta}.$$

它为零当且仅当 $0 \in \nabla f(\mathbf{w}) + \partial r(\mathbf{w})$ 。而 $\mathbf{G}_\eta(\mathbf{w}) + \nabla f(\mathbf{w}^+) - \nabla f(\mathbf{w})$ 属于 $\nabla f(\mathbf{w}^+) + \partial r(\mathbf{w}^+)$, 范数至多 $(1 + L\eta)\|\mathbf{G}_\eta(\mathbf{w})\|_2$, 所以这个停止残差确实控制新点的驻点性。若 F 下有界, 固定 $\eta \leq 1/L$ 时 $\min_{t < T} \|\mathbf{G}_\eta(\mathbf{w}^{(t)})\|_2^2 \leq 2(F(\mathbf{w}^{(0)}) - F_{\inf})/(\eta T)$ 。非凸 f 下这仍只是驻点保证。

若 f 也凸, 任意 $\mathbf{v} \in \text{dom } r$ 满足三点不等式

$$F(\mathbf{w}^+) - F(\mathbf{v}) \leq \frac{\|\mathbf{w} - \mathbf{v}\|_2^2 - \|\mathbf{w}^+ - \mathbf{v}\|_2^2}{2\eta} - \left(\frac{1}{2\eta} - \frac{L}{2}\right) \|\mathbf{w}^+ - \mathbf{w}\|_2^2.$$

它来自 f 在旧点的凸下界、在新点的光滑上界及 r 在新点的次梯度下界。取 $\mathbf{v} = \mathbf{w}^*$ 、 $\eta \leq 1/L$ 并求和, 便得 $F(\mathbf{w}^{(T)}) - F^* \leq \|\mathbf{w}^{(0)} - \mathbf{w}^*\|_2^2 / (2\eta T)$ 。未知 L 时, 可回溯增大二次模型系数直到 f 在新点不超过该模型; 每次试探都需重新求邻近解, 其成本应计入预算。

前面的唯一性来自给凸函数补入正二次曲率。如果原目标已经有少量负曲率, 二次距离是否仍能补足它? 弱凸性就是对所需补偿量的统一限制。

定义 4.15 欧氏空间中的弱凸性 设 $f: \mathbb{R}^d \rightarrow \mathbb{R} \cup \{+\infty\}$ 是适当函数, 即不恒为 $+\infty$, 且 $\rho \geq 0$ 。若 $\mathbf{w} \mapsto f(\mathbf{w}) + \rho \|\mathbf{w}\|_2^2/2$ 是凸函数, 则称 f 是 ρ 弱凸 (ρ -weakly convex) 的。取值 $+\infty$ 可以用来表示不可行点。

若 f 在开凸定义域上二阶可微, 这等价于 $\nabla^2 f(\mathbf{w}) \geq -\rho \mathbf{I}$: 负曲率可以存在, 但有统一下界。当 $\rho > 0$ 且 $0 < \eta < 1/\rho$ 时, 对任意中心 $\mathbf{z}$, 邻近子问题的目标

$$f(\mathbf{w}) + \frac{1}{2\eta} \|\mathbf{w} - \mathbf{z}\|_2^2$$

是 $(1/\eta - \rho)$ 强凸函数; 若 $\rho = 0$, 任意 $\eta > 0$ 都具有同样的补足曲率作用。若 f 还下半连续, 把 $f + \rho \|\cdot\|_2^2/2$ 代入本节的直接增长证明, 剩余正二次项就保证子问题强制且有唯一解。这正是弱凸性与邻近方法的联系。补入二次曲率只让这个子问题更易控制, 并没有把原函数变成凸函数; 弱凸目标仍可局部极小点和鞍点, 也不保证求得原问题的全局最优解。

例如 $f(x) = \cos x$ 的二阶导数是 $-\cos x \geq -1$, 所以它是 1 弱凸的, 但仍有无穷多个局部低点。弱凸性限制谷之间最坏的负曲率, 并未消除这些谷。若在当前位置附近加上足够大的二次惩罚, 邻近子问题会得到唯一解; 改变当前位置后, 所解的却是另一个邻近子问题, 不能据此声称原函数只有一个最小点。前面非凸 PL 例 $f(x, y) = x^2 + 2 \sin^2 x$ 的 Hessian 下界为 $-2\mathbf{I}$, 因此它也为 2 弱凸; 这只说明两项性质可以共存, 不说明任意弱凸函数都满足 PL 条件。弱凸邻近映射一般也不再非扩张。例如 $f(x) = -\rho x^2/2$ 且 $0 < \eta\rho < 1$ 时, 其唯一邻近解为 $z/(1 - \eta\rho)$, 两个输入的距离被放大 $1/(1 - \eta\rho)$ 倍。

同一个低维族能显示这些性质各自控制什么。令

$$f_a(x_1, x_2) = \frac{1}{2}(x_1 + x_2)^2 + \frac{a}{2}(x_1 - x_2)^2.$$

当 $a > 0$ 时函数强凸; $a = 0$ 时它凸且满足 PL 条件, 但整条直线 $x_1 + x_2 = 0$ 都是最小点; $a < 0$ 时函数弱凸却无下界。若限制在紧可行域上, $a < 0$ 时仍有最小点, 但驻点 $(0, 0)$ 可能是鞍点。这个例子说明弱凸、PL 和强凸不是一条简单的强弱链: 弱凸限制最坏负曲率, PL 控制梯度与目标误差, 强凸还控制参数距离与唯一性。

4.4 有约束优化的求解

按负梯度走一步, 可能降低误差却超过预算。如何在降低目标的同时满足约束? 投影把越界候选拉回允许范围; 惩罚把违反约束的程度加到目标中; 乘子方法则调整约束的系数, 使目标与约束在最优处达到平衡, 并用对

条件	直接控制什么	单凭该条件不能得到什么
凸性	全部线段上的弦上界；局部最小点也是全局最小点	最小点存在、唯一或统一收敛速率
严格凸性	非平凡线段上的严格不等式；最小点至多一个	一致正曲率下界，例如 x^4 在原点曲率为零
强凸性	函数值相对切平面的二次增长（可微情形）	梯度光滑性，例如 $ x + \mu x^2/2$ 仍有尖点
弱凸性	最坏负曲率的统一下界	驻点全局最优或最小点唯一
PL 条件	梯度大小控制目标值差	凸性或参数解的唯一性

表 4.1 曲率条件的职责比较。各行针对不同性质，不能排成一条从“弱”到“强”的完整等级。

偶值判断还有多大改进空间。这些方法可以组合，但都要单独核验最终候选是否可行。

4.4.1 投影方法

对非空闭凸集 C ，约束指标 ι_C 适当、下半连续且凸，其邻近子问题只在 C 内比较平方距离。因此欧氏投影（projection） $\Pi_C(\mathbf{z}) = \arg \min_{\mathbf{w} \in C} \|\mathbf{w} - \mathbf{z}\|_2^2$ 把一步梯度更新拉回可行域：

$$\mathbf{w}^{(t+1)} = \Pi_C(\mathbf{w}^{(t)} - \eta^{(t)} \nabla f(\mathbf{w}^{(t)})).$$

这就是取 $r = \iota_C$ 的近端梯度。邻近存在与非扩张证明已经适用；下面将其中的最近点几何明确写出，后面对分离的证明将直接回用它。若 C 非凸，最近点可能不唯一。

最近点的直接几何证明。任取 $\mathbf{x}_0 \in C$ 并令 $R = \|\mathbf{z} - \mathbf{x}_0\|_2$ 。集合

$$C_R = C \cap \{\mathbf{x} : \|\mathbf{z} - \mathbf{x}\|_2 \leq R\}$$

非空、闭且有界，因而在有限维空间中紧。连续函数 $\|\mathbf{z} - \mathbf{x}\|_2^2$ 在 C_R 上达到最小值；球外各点到 $\mathbf{z}$ 的距离大于 R ，而 $\mathbf{x}_0$ 的距离等于 R ，所以该最小点也是 C 上的最近点。若 $\mathbf{p}_1, \mathbf{p}_2$ 都是最近点，最近距离为 δ ，则凸性保证其中点属于 C ，且

$$\left\| \mathbf{z} - \frac{\mathbf{p}_1 + \mathbf{p}_2}{2} \right\|_2^2 = \frac{1}{2} \|\mathbf{z} - \mathbf{p}_1\|_2^2 + \frac{1}{2} \|\mathbf{z} - \mathbf{p}_2\|_2^2 - \frac{1}{4} \|\mathbf{p}_1 - \mathbf{p}_2\|_2^2.$$

当 $\mathbf{p}_1 \neq \mathbf{p}_2$ 时，右端严格小于 δ^2 ，与最近距离的定义矛盾，故最近点唯一，记为 $\mathbf{p}$ 。

对任意 $\mathbf{x} \in C$ ， $\mathbf{p} + t(\mathbf{x} - \mathbf{p}) \in C$ 。函数 $q(t) = \|\mathbf{z} - \mathbf{p} - t(\mathbf{x} - \mathbf{p})\|_2^2$ 在 $t = 0$ 处右导数非负，所以 $\langle \mathbf{z} - \mathbf{p}, \mathbf{x} - \mathbf{p} \rangle \leq 0$ 。展开 $\|\mathbf{z} - \mathbf{x}\|_2^2$ 即得

$$\|\mathbf{p} - \mathbf{x}\|_2^2 + \|\mathbf{z} - \mathbf{p}\|_2^2 \leq \|\mathbf{z} - \mathbf{x}\|_2^2, \quad \mathbf{x} \in C. \quad (4.23)$$

■

这说明投影不增加到任何可行参照点的距离；两个投影输出间的非扩张性则回用邻近证明。盒约束投影只需逐坐标截断，成本为 $O(d)$ 。若要求非负坐标之和为 1，得到概率单纯形 (probability simplex) $\Delta = \{\mathbf{w} \in \mathbb{R}^d : w_j \geq 0, \sum_j w_j = 1\}$ 。它的投影具有共同阈值形式

$$p_j = \max\{z_j - \tau, 0\}, \quad \sum_j \max\{z_j - \tau, 0\} = 1.$$

阈值同时移动全部坐标，由总和约束确定，不能像盒投影那样完全分开计算。为核对该形式，对 $p_j > 0$ 有 $z_j - p_j = \tau$ ，对 $p_j = 0$ 有 $z_j \leq \tau$ 。故对任意 $\mathbf{x} \in \Delta$ ， $\langle \mathbf{z} - \mathbf{p}, \mathbf{x} - \mathbf{p} \rangle \leq \tau \sum_j (x_j - p_j) = 0$ ；展开平方距离便知 $\mathbf{p}$ 确为最近点。常用实现先排序以确定哪些坐标为正，再解总和为 1 的阈值；一般凸集的投影则可能本身就是大型子问题。在共同二次目标上加范围 $C = [1, 2] \times [0, 2]$ ， $\eta = 0.1$ 的第一步先到 $(1.8, -1.2)$ ，再投影为 $(1.8, 0)$ 。约束最小点为 $(1, 0)$ ，其普通梯度为 $(1, 0)$ 而非零；正确停止量是 $\|\mathbf{w} - \Pi_C(\mathbf{w} - \eta \nabla f(\mathbf{w}))\|_2 / \eta$ 。它与原始可行性一起检查。若 f 凸且 L 光滑、最小点存在，前节三点不等式在 $\eta \leq 1/L$ 下直接给出目标差 $O(1/T)$ ，无需为投影另假设普通梯度在边界消失。

图 4.3 对同一个标量输入 z 比较三种处理：区间投影把超出范围的值截到边界；软阈值把小幅值置零、其余幅值减去固定量；二次惩罚则等比例缩小所有输入。投影保持可行性，软阈值产生稀疏性，二次惩罚改变幅度，它们都可以写成邻近算子，但输出行为和所解决的问题不同。




图 4.3 同一输入 z 的三种邻近映射。投影采用 $C = [-1, 1]$ ；软阈值与二次收缩均取 $\eta\lambda = 1$ ，分别输出 $\text{sign}(z)(|z| - 1)_+$ 和 $z/2$ 。横轴刻度标出阈值位置，曲线由完整分段解析式生成。

更新方式	每步处理的结构	分析前需核对的条件
梯度下降	使用可微目标的梯度	光滑常数与步长；全局最优保证还依赖凸性或 PL 等条件
投影梯度	梯度更新后求可行集最近点	非空闭凸集；投影本身的计算成本
次梯度更新	使用非光滑凸目标的全局下界斜率	次梯度范数及步长序列；单步目标未必下降
近端梯度	光滑部分求梯度，非光滑部分求邻近解	光滑部分的步长、正则项的适当闭凸性及可解邻近子问题

表 4.2 常见一阶更新的结构与条件。相近的更新形式并不共享同一收敛定理。

4.4.2 惩罚方法

寻找最近的可行点可能很贵，而计算违反约束的程度通常较容易。将等式写为 $a_j(\mathbf{w}) = 0$ 、不等式写为 $g_k(\mathbf{w}) \leq 0$ ，并记 $[u]_+ = \max\{u, 0\}$ 。等式偏离零的绝对值，以及不等式超过零的部分，都代表违反量。因此可以取 $V(\mathbf{w}) = \sum_j |a_j(\mathbf{w})| + \sum_k [g_k(\mathbf{w})]_+$ ，再最小化 $f + \rho V$ ；也可以用平方残差构造光滑的二次惩罚。参数 ρ 越大，算法越重视可行性，但两类惩罚的有限参数性质不同。

对共同二次目标加等式 $w_1 + w_2 = 1$ ，二次惩罚问题为

$$\min_{\mathbf{w}} \frac{1}{2}(w_1^2 + 16w_2^2) + \frac{\rho}{2}(w_1 + w_2 - 1)^2.$$

解线性驻点方程得

$$\mathbf{w}_\rho = \frac{(16\rho, \rho)^\top}{16 + 17\rho}, \quad w_{\rho,1} + w_{\rho,2} - 1 = -\frac{16}{16 + 17\rho}.$$

任意有限 $\rho > 0$ 下它仍不可行，极限才是约束解 $(16/17, 1/17)$ 。惩罚 Hessian 为 $\text{diag}(1, 16) + \rho \mathbf{1}\mathbf{1}^\top$ ，最大特征值随 ρ 增大，最小特征值趋向 $17/2$ ；条件数逐渐恶化，光滑梯度法需要更小步长，不能只把增大参数看作免费提高精度。

一般可行性极限也有前提。设 $P \geq 0$ 连续且 $P = 0$ 恰好表示可行， f 下半连续并在候选区域有统一有限下界 m ， $\mathbf{w}_\rho$ 精确最小化 $f + \rho P$ ，并存在可行 $\bar{\mathbf{w}}$ 。则 $\rho P(\mathbf{w}_\rho) \leq f(\bar{\mathbf{w}}) - m$ ，所以 $\rho \rightarrow \infty$ 时违反量趋零。若这些解还有有界子列，其极限可行；再与任意可行点比较并使用下半连续性，可知极限全局最优。没有有界性不能保证存在极限，近似子问题则还要将求解误差加入这个比较。

非平方的惩罚可能在有限参数精确。例如区域内 f 是 K -Lipschitz，且每个候选都有可行修复 $\mathbf{p}$ 满足 $\|\mathbf{p} - \mathbf{w}\|_2 \leq \kappa V(\mathbf{w})$ ，则

$$f(\mathbf{w}) + \rho V(\mathbf{w}) \geq f(\mathbf{p}) + (\rho - K\kappa)V(\mathbf{w}).$$

当 $\rho > K\kappa$ 时, 任何不可行点都不如它的修复点, 因而惩罚最优解必须可行。这是一条带明确误差界的精确性条件, 不是所有惩罚的共同结论; 后文还将用达到的乘子给出另一种参数对应。

范数约束 $\|\mathbf{w}\|_1 \leq R$ 直接排除超出半径 R 的参数; 正则项 $\lambda\|\mathbf{w}\|_1$ 则按参数绝对值之和增加代价, 不直接强制某个预先给定的 R 。含绝对值的惩罚可调用次梯度或邻近方法; 二次惩罚可调用光滑方法。外层逐步提高 ρ 时, 内层既要报告原目标变化, 也要报告约束违反量, 不能仅凭惩罚目标的小梯度停机。

同样的区别出现在权重衰减中。普通欧氏梯度下降用于 $f(\mathbf{w}) + \lambda\|\mathbf{w}\|_2^2/2$ 时给出

$$\mathbf{w}^{(t+1)} = (1 - \eta\lambda)\mathbf{w}^{(t)} - \eta\nabla f(\mathbf{w}^{(t)}),$$

与直接乘上衰减因子相同。若使用预条件矩阵 $\mathbf{P}$, 惩罚梯度产生 $-\eta\lambda\mathbf{P}\mathbf{w}^{(t)}$, 而坐标无关的直接衰减仍为 $-\eta\lambda\mathbf{w}^{(t)}$; 除非 $\mathbf{P} = \mathbf{I}$ 或另有匹配, 它们不再相同。

4.4.3 乘子与对偶方法

惩罚方法由我们指定违反约束的代价。乘子方法则要寻找一组系数, 使最优点处的目标梯度能与约束的法向量抵消: 即使目标梯度不为零, 允许的方向也已不能继续改善目标。下面先说明怎样用这种平衡判断最优, 再说明怎样用对偶下界估计差距, 最后给出寻找乘子的更新。

4.4.3.1 乘子条件与局部最优

资源约束使最优点处的目标梯度不必为零, 因为可行方向受到限制。对

$$\min_{\mathbf{w}} f(\mathbf{w}) \quad \text{s.t.} \quad a_j(\mathbf{w}) = 0 \ (j = 1, \dots, m), \quad g_k(\mathbf{w}) \leq 0 \ (k = 1, \dots, p),$$

例如约束 $x \leq a$: 当 $x < a$ 时, 小幅左右移动都仍可行; 当 $x = a$ 时, 只能向左移动。后者称为约束活跃, 它开始限制当前点的移动方向。

定义 4.16 活跃约束与线性化可行方向 设约束函数在可行点 $\mathbf{w}$ 处可微。不等式 $g_k(\mathbf{w}) \leq 0$ 在该点活跃, 是指 $g_k(\mathbf{w}) = 0$ 。满足

$$\langle \nabla a_j(\mathbf{w}), \mathbf{d} \rangle = 0, \quad \langle \nabla g_k(\mathbf{w}), \mathbf{d} \rangle \leq 0 \quad \text{对所有活跃的 } g_k$$

的方向 $\mathbf{d}$ 称为一阶可行方向 (linearized feasible direction)。

这些关系只检验约束的一阶近似, 不保证 $\mathbf{w} + t\mathbf{d}$ 在任意小的正 t 下都可行。例如约束 $x^2 \leq 0$ 在 0 处梯度为零, 线性化允许任何方向, 真实可行点却只有 0; 后面的资格条件正是为了防止这种一阶信息失真。等式约

束为何产生法向量平衡，可以先看仿射情形 $\mathbf{A}\mathbf{w} = \mathbf{b}$ 。任一可行扰动都满足 $\mathbf{A}\mathbf{d} = \mathbf{0}$ ；局部最优点不能沿 $\mathbf{d}$ 或 $-\mathbf{d}$ 下降，故 $\langle \nabla f(\mathbf{w}^*), \mathbf{d} \rangle = 0$ 对所有 $\mathbf{d} \in \ker \mathbf{A}$ 成立。由 $(\ker \mathbf{A})^\perp = \text{range}(\mathbf{A}^\top)$ ，存在不受符号限制的 $\boldsymbol{\nu}$ 使 $\nabla f(\mathbf{w}^*) = -\mathbf{A}^\top \boldsymbol{\nu}$ 。这里的法向量指与所有切向可行扰动垂直的向量； $\mathbf{A}$ 的行给出等式面的法向量。在共同二次目标加 $w_1 + w_2 = 1$ 的例子中，平衡方程为 $w_1 + \nu = 0$ 、 $16w_2 + \nu = 0$ 和 $w_1 + w_2 = 1$ ，解出 $\nu = -16/17$ 、 $\mathbf{w} = (16/17, 1/17)^\top$ 。这里 ν 是等式梯度的系数，不要求非负。等式两侧的偏离都不允许，因此它不像不等式预算那样只限制一个方向。

活跃不等式只允许切平面一侧的一阶移动，它的外法向量因而以非负系数参与梯度平衡；不活跃约束在该点留有严格余量，不限制足够小的移动，对应系数应为零。这分别引出非负乘子与互补松弛。在适当的约束资格条件下，这些几何关系可通过拉格朗日函数（Lagrangian）统一表达：

$$\mathcal{L}(\mathbf{w}, \boldsymbol{\nu}, \boldsymbol{\alpha}) = f(\mathbf{w}) + \sum_j \nu_j a_j(\mathbf{w}) + \sum_k \alpha_k g_k(\mathbf{w}), \quad \boldsymbol{\nu} \in \mathbb{R}^m, \quad \boldsymbol{\alpha} \in \mathbb{R}_+^p.$$

这个函数把原目标与各约束函数加权相加。乘子将被选择为使目标梯度与约束梯度平衡的系数；它们的取值要由后面的条件决定。

定义 4.17 KKT 条件 对于上述可微约束问题，候选点 $\mathbf{w}^*$ 与乘子 $\boldsymbol{\nu}^* \in \mathbb{R}^m$ 、 $\boldsymbol{\alpha}^* \in \mathbb{R}^p$ 满足 Karush-Kuhn-Tucker 条件 (KKT conditions)，是指以下四组关系同时成立：

$$\nabla_{\mathbf{w}} \mathcal{L}(\mathbf{w}^*, \boldsymbol{\nu}^*, \boldsymbol{\alpha}^*) = \mathbf{0}, \quad \text{驻点性,} \quad (4.24)$$

$$a_j(\mathbf{w}^*) = 0, \quad g_k(\mathbf{w}^*) \leq 0, \quad \text{原始可行性,} \quad (4.25)$$

$$\alpha_k^* \geq 0, \quad \text{对偶可行性,} \quad (4.26)$$

$$\alpha_k^* g_k(\mathbf{w}^*) = 0, \quad \text{互补松弛.} \quad (4.27)$$

等式、不等式约束分别对全部 $j = 1, \dots, m$ 与 $k = 1, \dots, p$ 检验。

互补松弛要求：约束留有严格余量时，其乘子必须为零；乘子为正时，相应约束必须恰好取等号。例如，预算还未用尽时，就不能给这项预算赋予正的边际价格。

局部最优点满足 KKT 条件需要约束资格条件 (constraint qualification)。这里采用一个局部、容易核验的充分条件： f, a_j, g_k 在点附近连续可微，全部等式梯度与活跃不等式梯度线性无关，称为线性无关约束资格条件 (LICQ)。它与后面保证凸问题强对偶的 Slater 条件不是同一个假设。

可借第 3 章的逆函数工具直接证明 LICQ 下的必要性，无需提前使用后面的分离定理。把等式值、活跃不等式值与适当补充的线性坐标组成 $\mathbf{T}(\mathbf{w}) = (\mathbf{a}(\mathbf{w}), \mathbf{g}_I(\mathbf{w}), \mathbf{z}(\mathbf{w}))$ 。线性无关性使补充后的 Jacobian 可逆， $\mathbf{T}$ 在

局部就是可逆坐标变换。未活跃不等式仍严格满足；新坐标中的可行域局部恰为 $\mathbf{a} = 0$, $\mathbf{g}_l \leq 0$, 而 $\mathbf{z}$ 自由。局部最优时, 自由坐标偏导为零, 活跃不等式坐标只能朝负方向移动, 故相应目标偏导非正。取 ν_j 为等式坐标偏导的相反数、 α_k 为活跃不等式坐标偏导的相反数, 再令未活跃乘子为零, 链式法则恰给 $\nabla f + \sum_j \nu_j \nabla a_j + \sum_k \alpha_k \nabla g_k = 0$ 。非负性与互补松弛同时成立, 这就建立了局部必要性。

没有资格条件, 乘子可能不存在。例 $f(x) = x$ 且约束 $x^2 \leq 0$ 只有可行点 $x = 0$, 它当然最优; 但约束梯度为零, 驻点条件 $1 + \alpha \cdot 0 = 0$ 无解。

反方向在凸情形更强。若 f 和每个 g_k 均为可微凸函数, a_j 仿射, 且某个可行点与乘子满足 KKT, 则对任意可行 $\mathbf{w}$, 仿射等式约束使 $\langle \nabla a_j(\mathbf{w}^*), \mathbf{w} - \mathbf{w}^* \rangle = a_j(\mathbf{w}) - a_j(\mathbf{w}^*) = 0$ 。因此等式乘子项消失, 再由凸性和驻点性,

$$f(\mathbf{w}) \geq f(\mathbf{w}^*) - \sum_k \alpha_k^* \langle \nabla g_k(\mathbf{w}^*), \mathbf{w} - \mathbf{w}^* \rangle \geq f(\mathbf{w}^*).$$

最后一步使用凸约束的一阶下界、可行性和互补松弛。因此 KKT 在该条件下足以保证全局最优。这个充分性证明不需要 LICQ 或 Slater: 只要确实找到满足 KKT 的候选即可。反过来, 非凸问题即便 LICQ 成立, KKT 也通常只是必要条件; 例如无约束 $f(x) = -x^2$ 在 0 满足驻点条件, 却是极大点。数值计算只能得到近似关系, 宜分别报告 $\|\nabla_{\mathbf{w}} \mathcal{L}\|_2$ 、 $\|\mathbf{a}\|_2$ 、 $\|[\mathbf{g}]_+\|_2$ 、 $\|[-\alpha]_+\|_2$ 及 $\|\mathbf{a} \odot \mathbf{g}\|_2$, 其中 $\odot$ 表示逐坐标乘积。这些残差小, 表示上述关系近似成立, 却未必表示目标接近最优值: 即使无约束凸目标 $f(x) = \epsilon x^2/2$, 梯度大小 δ 也对应目标差 $\delta^2/(2\epsilon)$, 仍须知道曲率尺度。若已找到精确可行点及可信的对偶下界, 才可直接用二者的差控制全局目标误差。

示例 4.18 活跃约束与乘子 最小化 $f(x) = (x-2)^2/2$, 约束 $x \leq a$ 。无约束最小点为 2, 因此 $x^*(a) = \min\{2, a\}$ 。将约束写成 $g(x) = x-a \leq 0$, KKT 条件为 $x-2+u=0$ 、 $u \geq 0$ 、 $x \leq a$ 与 $u(x-a)=0$ 。当 $a=1$ 时, $x^*=1$ 、 $u^*=1$; 当 $a=3$ 时, $x^*=2$ 、 $u^*=0$ 。当 $a=1$ 时, 约束阻止 x 继续向 2 移动, 正乘子抵消目标梯度; 当 $a=3$ 时, 无约束最小点已被允许, 乘子为零。最优值为 $v(a) = (2-a)^2/2$ 对 $a < 2$ 成立, $a \geq 2$ 时为零。在 $a=1$ 附近, $v'(a) = a-2 = -u^*$: 增加一小单位资源上限, 最优代价下降的局部速率由乘子给出。到 $a=2$ 时活跃集改变, 解映射出现折点, 不能跨越它直接沿用同一敏感性公式。

示例 4.19 预算约束、活跃集与敏感性 求最接近 $\mathbf{c} = (2, 1)^\top$ 的非负分配，并令总预算为 $\tau > 0$ ：

$$\min_{\mathbf{w}} \frac{1}{2} \|\mathbf{w} - \mathbf{c}\|_2^2 \quad \text{s.t.} \quad w_1 + w_2 \leq \tau, \quad -w_1 \leq 0, \quad -w_2 \leq 0.$$

当 $\tau > 3$ 时， $\mathbf{c}$ 本身严格满足预算约束，故该约束不活跃，且 $\mathbf{w}^*(\tau) = (2, 1)^\top$ 。当 $\tau = 3$ 时解仍为 $\mathbf{c}$ ，预算约束活跃，但其乘子为零；这个边界说明“约束活跃”不等于“乘子严格为正”。当 $1 < \tau < 3$ 时，两个坐标仍为正而预算取等。把预算这一不等式的乘子记为 α_{bud} ，驻点条件给

$$w_1 - 2 + \alpha_{\text{bud}} = 0, \quad w_2 - 1 + \alpha_{\text{bud}} = 0, \quad w_1 + w_2 = \tau.$$

因此

$$\mathbf{w}^*(\tau) = \left(\frac{\tau+1}{2}, \frac{\tau-1}{2} \right)^\top, \quad \alpha_{\text{bud}}^*(\tau) = \frac{3-\tau}{2}.$$

当 $0 < \tau < 1$ 时，第二个非负约束也活跃，解变成 $\mathbf{w}^*(\tau) = (\tau, 0)^\top$ ，预算乘子为 $2 - \tau$ ，第二个非负约束的乘子为 $1 - \tau$ 。在 $\tau = 1$ 处，第二个非负约束活跃但乘子为零。上述区域及边界分别展示预算不生效、约束活跃但零乘子、仅预算产生正价格，以及预算与坐标边界同时产生正价格。目标严格凸，满足 KKT 的点都是唯一全局最优解。

4.4.3.2 对偶下界与全局最优

对固定乘子 $\boldsymbol{\alpha} \geq \mathbf{0}$ ，任意可行 $\mathbf{w}$ 都满足 $\mathcal{L}(\mathbf{w}, \boldsymbol{\nu}, \boldsymbol{\alpha}) \leq f(\mathbf{w})$ 。因此对偶函数 (dual function)

$$q(\boldsymbol{\nu}, \boldsymbol{\alpha}) = \inf_{\mathbf{w}} \mathcal{L}(\mathbf{w}, \boldsymbol{\nu}, \boldsymbol{\alpha})$$

给出原问题最优值的下界。改变乘子、寻找最大的下界，就得到对偶问题。把原问题与对偶问题的最优值分别记为 p^* 和 d^* ，由构造立即有 $d^* \leq p^*$ ，称为弱对偶 (weak duality)；差 $p^* - d^*$ 称为对偶间隙。对某组乘子取下确界得到 $-\infty$ ，表示这组乘子没有给出有限下界；对偶不可行则表示没有任何乘子满足对偶问题规定的可行条件。前者描述一个候选乘子的函数值，后者描述整个候选集合，二者不能混用。若已求得原始可行 $\hat{\mathbf{w}}$ 与有限对偶值 $q(\boldsymbol{\nu}, \boldsymbol{\alpha})$ ，则 $f(\hat{\mathbf{w}}) - q(\boldsymbol{\nu}, \boldsymbol{\alpha})$ 是可核验的目标差上界。接下来要回答：这样的下界是否足够紧，能否达到原问题的最优值？先证明一个集外点能被线性不等式与闭凸集分开，再用这些不等式重建凸函数。在线性约束问题中，还要证明不可行性能由一个向量验证。这几步将分别支持一般凸函数的表示和线性规划的强对偶证明。

定理 4.20 闭凸集外一点的严格分离 设 $C \subseteq \mathbb{R}^d$ 非空、闭且凸, $\mathbf{z} \notin C$ 。则存在 $\mathbf{a} \neq \mathbf{0}$ 和 $c \in \mathbb{R}$, 使

$$\langle \mathbf{a}, \mathbf{x} \rangle \leq c < \langle \mathbf{a}, \mathbf{z} \rangle \quad \text{对所有 } \mathbf{x} \in C.$$

证明. 由投影小节的直接证明, $\mathbf{p} = \Pi_C(\mathbf{z})$ 存在且唯一, 并满足 $\langle \mathbf{z} - \mathbf{p}, \mathbf{x} - \mathbf{p} \rangle \leq 0$ 对所有 $\mathbf{x} \in C$ 成立。取 $\mathbf{a} = \mathbf{z} - \mathbf{p}$ 和 $c = \langle \mathbf{a}, \mathbf{p} \rangle$ 。由于 $\mathbf{z} \notin C$, $\mathbf{a} \neq \mathbf{0}$, 并且 $\langle \mathbf{a}, \mathbf{x} \rangle \leq c$, 而 $\langle \mathbf{a}, \mathbf{z} \rangle = c + \|\mathbf{a}\|_2^2 > c$ 。 ■

如果把分隔两个对象的超平面移到集合边界, 使集合仍全部留在一侧, 边界接触处就得到一个支撑超平面。后面还需检查某个向量能否由约束向量的非负组合得到, 因此要引入另一类集合: 若允许对向量任意作非负缩放和相加, 所得集合称为凸锥。

定义 4.21 支撑超平面与凸锥 设 $C \subseteq \mathbb{R}^d$ 非空, $\mathbf{a} \neq \mathbf{0}$ 。若 C 全部位于 $\{\mathbf{x} : \langle \mathbf{a}, \mathbf{x} \rangle \leq c\}$, 并且至少有一点取等号, 则等号超平面称为 C 的支撑超平面 (supporting hyperplane)。非空集合 K 若对所有 $\mathbf{u}, \mathbf{v} \in K, \alpha, \beta \geq 0$ 都有 $\alpha\mathbf{u} + \beta\mathbf{v} \in K$, 称为凸锥。

具体地说, 若 $\mathbf{p}$ 位于闭凸集 C 的边界, 可取一系列集外点 $\mathbf{z}^{(k)} \rightarrow \mathbf{p}$, 对每个点应用严格分离并把法向量归一化。单位球的紧性给出收敛子列, 极限法向量 $\mathbf{a} \neq \mathbf{0}$ 满足 $\langle \mathbf{a}, \mathbf{x} \rangle \leq \langle \mathbf{a}, \mathbf{p} \rangle$ 对所有 $\mathbf{x} \in C$ 成立。这说明边界处至少有一个支撑方向, 但边界有棱角时法向量未必唯一。分离把“点不属于集合”转化为一个线性不等式证书, 但它本身不自动给出一般凸问题的强对偶; 还需要闭性或约束资格条件。

对称矩阵集合中的半正定锥 (positive semidefinite cone)

$$\mathbb{S}_+^d = \{\mathbf{M} = \mathbf{M}^\top : \mathbf{v}^\top \mathbf{M} \mathbf{v} \geq 0, \forall \mathbf{v}\}$$

是凸锥, 因为非负线性组合仍保持二次型非负。它也是闭集: 若 $\mathbf{M}^{(k)} \rightarrow \mathbf{M}$ 且每个 $\mathbf{M}^{(k)} \geq \mathbf{0}$, 则对任意固定 $\mathbf{v}$ 都有 $\mathbf{v}^\top \mathbf{M} \mathbf{v} = \lim_k \mathbf{v}^\top \mathbf{M}^{(k)} \mathbf{v} \geq 0$ 。线性规划中的逐坐标非负约束, 以及半正定规划中的矩阵半正定约束, 都定义凸可行域。标准凸二次规划使用半正定矩阵的作用不同: 它保证目标函数凸。这几类问题都在凸集上最小化凸目标, 但半正定条件作用于不同对象。若要进一步统一成带线性目标的锥规划, 还需引入辅助变量, 用锥约束表达二次目标的界。

分离用仿射函数区分一个点与可行集合。对目标函数, 也可以收集所有仿射下界: 固定斜率后找最紧的截距, 再比较所有斜率能否重建原函数。凸共轭承担这一步。

上图集 $\text{epi } f = \{(\mathbf{x}, r) \in \mathbb{R}^{d+1} : r \geq f(\mathbf{x})\}$ 记录图像以上的全部点；它凸与 f 凸等价，闭与 f 下半连续等价。

定义 4.22 凸共轭与双共轭 给定适当函数 $f : \mathbb{R}^d \rightarrow \mathbb{R} \cup \{+\infty\}$ ，其凸共轭 (convex conjugate) 定义为

$$f^*(\mathbf{y}) = \sup_{\mathbf{x} \in \mathbb{R}^d} \{\langle \mathbf{y}, \mathbf{x} \rangle - f(\mathbf{x})\}, \quad f^{**}(\mathbf{x}) = \sup_{\mathbf{y} \in \mathbb{R}^d} \{\langle \mathbf{y}, \mathbf{x} \rangle - f^*(\mathbf{y})\}. \quad (4.28)$$

两个上确界都在整个 $\mathbb{R}^d$ 上取。 f^* 允许取 $+\infty$ ；若 $f^* \equiv +\infty$ ，则 $f^{**} \equiv -\infty$ ，否则 f^{**} 不取 $-\infty$ ，但仍可能取 $+\infty$ 。

这里 $f(\mathbf{x}) = +\infty$ 的点不贡献有限共轭候选。固定斜率 $\mathbf{y}$ 时， $f^*(\mathbf{y})$ 是让 $\langle \mathbf{y}, \mathbf{x} \rangle - f^*(\mathbf{y})$ 在全域不超过 f 所需的最小截距修正。

示例 4.23 由斜率重建二次函数 仍取图 4.1 中的 $f(x) = x^2/2$ 。固定直线斜率 y ，配方得到

$$yx - \frac{x^2}{2} = \frac{y^2}{2} - \frac{(x-y)^2}{2}.$$

右边在 $x = y$ 时达到最大值，所以 $f^*(y) = y^2/2$ 。这个共轭值确定了该斜率下最高的仿射下界

$$\ell_y(x) = yx - \frac{y^2}{2}, \quad f(x) - \ell_y(x) = \frac{(x-y)^2}{2} \geq 0. \quad (4.29)$$

直线 ℓ_y 在 $x = y$ 处与抛物线相切；再提高截距，就会在该点超过 f 。现在固定输入 x ，让斜率 y 变化。每条直线都在 f 下方，而选择 $y = x$ 就能在这个输入处达到 $f(x)$ ，因此

$$f^{**}(x) = \sup_{y \in \mathbb{R}} \ell_y(x) = \frac{x^2}{2}.$$

共轭把函数转换成“每个斜率允许多高的下界”，双共轭则在每个输入处取这些下界中最高的值。图 4.4 只画三个斜率；它们的逐点最大值是折线，只有纳入所有实数斜率，才能在每个输入处恢复这条抛物线。

没有任何仿射下界时，这个修正对每个斜率都为无穷。例如 $f(x) = -x^2$ 满足 $f^*(y) = \sup_x \{yx + x^2\} = +\infty$ ，双共轭因而恒为 $-\infty$ ；适当性本身不能排除这一情形。由定义立即有 Fenchel-Young 不等式

$$f(\mathbf{x}) + f^*(\mathbf{y}) \geq \langle \mathbf{y}, \mathbf{x} \rangle,$$




图 4.4 $f(x) = x^2/2$ 与斜率 $y = -1, 0, 1$ 对应的仿射下界 $\ell_y(x) = yx - y^2/2$ 。蓝实线为抛物线，三条灰虚线为下界，红实线为这三条下界的逐点最大值。三个实心点标出相切位置；有限个斜率留下的间隙，在取全部斜率的上确界时消失。图为解析教学示例。

以及 $f^{**} \leq f$ 。共轭是仿射函数族的上确界，因而凸且下半连续；它并非简单把函数图像交换横纵坐标，也不要求每个上确界都由有限斜率达到。

定理 4.24 有限维 Fenchel-Moreau 定理 设 $f : \mathbb{R}^d \rightarrow \mathbb{R} \cup \{+\infty\}$ 适当、下半连续且凸。则 $f^{**} = f$ 在全部 $\mathbb{R}^d$ 上成立，包括 $f(x) = +\infty$ 的点。因此 f 恰好是全部连续仿射下界的逐点上确界。

证明. 上图集 $\text{epi } f = \{(x, r) : r \geq f(x)\}$ 非空、闭且凸。任取 $x_0 \in \text{dom } f$ 及 $t_0 < f(x_0)$ ，对上图与其外一点 (x_0, t_0) 使用定理 4.20，得到

$$\langle a, x_0 \rangle + bt_0 < c \leq \langle a, z \rangle + br \quad \text{对所有 } (z, r) \in \text{epi } f.$$

上图沿 r 向上无界，故 $b \geq 0$ ；若 $b = 0$ ，取 $(z, r) = (x_0, f(x_0))$ 便矛盾，所以 $b > 0$ 。重排得到一个全域仿射下界 $\ell_0(z) = \langle p_0, z \rangle - \beta_0 \leq f(z)$ 。这也保证 $f^*(p_0)$ 有限。

现任取 x 和实数 $t < f(x)$ ，再次严格分离 (x, t) 与上图。若所得竖系数 $b > 0$ ，立即得到一个仿射下界 ℓ ，满足 $\ell(x) > t$ 。若 $b = 0$ ，分离不等式为 $\langle a, x \rangle < c \leq \langle a, z \rangle$ 。将它与 $\varepsilon(r - \ell_0(z)) \geq 0$ 相加，得到

$$\langle a - \varepsilon p_0, z \rangle + \varepsilon r \geq c - \varepsilon \beta_0.$$

取足够小的 $\varepsilon > 0$ ，在 (x, t) 处仍为严格反向不等式，因为原来的分离间隙为正。新的竖系数为 $\varepsilon > 0$ ，因此仍得到 $\ell \leq f$ 且 $\ell(x) > t$ 。

将这一仿射下界写为 $\ell(\mathbf{z}) = \langle \mathbf{y}, \mathbf{z} \rangle - \beta$, 有 $f^*(\mathbf{y}) \leq \beta$, 所以 $f^{**}(\mathbf{x}) \geq \langle \mathbf{y}, \mathbf{x} \rangle - f^*(\mathbf{y}) \geq \ell(\mathbf{x}) > t$. 若 $f(\mathbf{x})$ 有限, 令 $t \uparrow f(\mathbf{x})$; 若 $f(\mathbf{x}) = +\infty$, 让 t 任意增大, 两种情形均得 $f^{**}(\mathbf{x}) \geq f(\mathbf{x})$. 结合反向不等式即得结论。■

例 4.23 已经用切线族重建了二次函数; 定理将这个结论推广到可能不可微、允许取 $+\infty$ 的闭凸目标。若 $f = \iota_{[0,1]}$ 为闭区间指标函数, 则 $f^*(y) = \max\{0, y\}$, 双共轭恢复区间内的零值和区间外的 $+\infty$ 。闭性不能省略: 对开区间指标 $f = \iota_{(0,1)}$, 共轭仍为 $\max\{0, y\}$, 但双共轭成为 $\iota_{[0,1]}$, 在两个端点补上零值。仿射下界无法区分一个边界点与从内部趋近的极限, 下半连续性正是排除这种缺口的条件。

函数等于双共轭也不保证边界处有有限的最优斜率。例如闭凸函数 $f(x) = -\sqrt{x}$ 对 $x \geq 0$ 定义, 负半轴取 $+\infty$ 。在 $x = 0$, 有限次梯度 y 若存在, 必须满足 $-\sqrt{x} \geq yx$ 对所有 $x > 0$ 成立, 即 $y \leq -1/\sqrt{x}$, 这是不可能的。 $f^{**}(0) = f(0) = 0$ 仍成立, 但只能由一系列仿射下界逼近, 不能声称共轭上确界在某个有限 y 处达到。由双共轭推导对偶表达时, 值相等与最优乘子存在必须分别证明。

要证明线性规划的对偶界可以逼近最优值, 可以先问: 为何不可能找到目标值更低的可行点? 若能把这种不可行性写成一个可检查的线性不等式, 就能从中构造对偶候选。下面先证明所需集合的闭性, 再建立这种“可行解与不可行证书恰有一个存在”的择一定理³。

³ S. Boyd, L. Vandenberghe, *Convex Optimization*, Cambridge University Press, 2004

引理 4.25 有限生成锥的闭性 给定 $\mathbf{a}_1, \dots, \mathbf{a}_r \in \mathbb{R}^m$, 集合

$$K = \left\{ \sum_{i=1}^r \alpha_i \mathbf{a}_i : \alpha_i \geq 0 \right\}$$

是闭凸锥。

证明. 凸性和锥性质由非负线性组合直接得到。为证明闭性, 先注意每个 $\mathbf{x} \in K$ 都能由一组线性无关的生成向量作非负组合。若某个表示使用的生成向量线性相关, 就存在非零系数 $\boldsymbol{\gamma}$ 使 $\sum_i \gamma_i \mathbf{a}_i = \mathbf{0}$; 必要时改变符号, 使至少一个 $\gamma_i > 0$ 。从原系数中减去 $t\boldsymbol{\gamma}$, 其中 $t = \min_{\gamma_i > 0} \alpha_i / \gamma_i$, 仍保持所有系数非负, 并使至少一个系数变为零。重复此过程便得到线性无关的表示。

现取 $\mathbf{x}^{(k)} \in K$ 且 $\mathbf{x}^{(k)} \rightarrow \mathbf{x}$ 。线性无关的生成子集只有有限多个, 故可取子列, 使每个 $\mathbf{x}^{(k)}$ 都使用同一个子集 J 。以这些向量为列组成满列秩矩阵 $\mathbf{A}_J$, 相应非负系数满足

$$\boldsymbol{\alpha}^{(k)} = (\mathbf{A}_J^\top \mathbf{A}_J)^{-1} \mathbf{A}_J^\top \mathbf{x}^{(k)} \longrightarrow (\mathbf{A}_J^\top \mathbf{A}_J)^{-1} \mathbf{A}_J^\top \mathbf{x}.$$

极限系数仍逐项非负, 且 $\mathbf{x}$ 等于 $\mathbf{A}_J$ 乘该极限系数, 故 $\mathbf{x} \in K$ 。■

除了得到任意接近最优值的候选, 还要保证最优值确实被达到。为此, 需要知道线性约束定义的候选集合经线性映射后仍然闭合, 特别是其目标值集合包含有限的端点。

引理 4.26 有限维多面体的线性像 有限个非严格线性不等式定义的集合称为多面体。有限维多面体在线性映射下的像仍是多面体, 因而是闭集。

证明. 设多面体 $P = \{u : Bu \leq d\}$, 线性映射为 $v = Tu$ 。其图像

$$\{(u, v) : Bu \leq d, v = Tu\}$$

是多面体, 而 TP 是该图像消去 u 后的坐标投影。对一个待消变量, Fourier-Motzkin 消元分别收集其系数为正、为负和为零的不等式; 每一对正、负系数不等式消去该变量, 零系数不等式原样保留。所得有限组非严格线性不等式恰好描述投影。逐个消去 u 的坐标, 便得到 TP 的有限线性不等式表示。多面体是有限个闭半空间的交, 因此闭。 ■

定理 4.27 Farkas 择一定理 给定 $M \in \mathbb{R}^{m \times d}$ 和 $r \in \mathbb{R}^m$, 下列两个系统恰有一个可行:

$$Mx = r, \quad x \geq 0; \quad M^T z \geq 0, \quad r^T z < 0.$$

证明. 两者不能同时成立, 因为若都成立, 则 $0 > r^T z = x^T M^T z \geq 0$, 矛盾。若第一个系统不可行, r 不属于锥 $K = \{Mx : x \geq 0\}$ 。它由 M 的有限个列向量生成, 故由引理 4.25 可知 K 是闭凸锥。对 K 与 r 应用定理 4.20, 得到 a 和 c , 使 $\langle a, k \rangle \leq c < \langle a, r \rangle$ 。由于 $0 \in K$, 有 $c \geq 0$; 又因为 $tk \in K$ 对所有 $t \geq 0$ 成立, 必有 $\langle a, k \rangle \leq 0$, 否则取充分大的 t 便会超过 c 。令 $z = -a$, 可得 $\langle z, r \rangle < 0$ 且 $\langle z, k \rangle \geq 0$ 对所有 $k \in K$ 成立。特别地, 对 M 的每个列向量成立, 故 $M^T z \geq 0$ 。第二个系统可行。 ■

定理 4.28 有限维线性规划强对偶 考虑标准型原问题与对偶问题

$$\min_{x \geq 0} c^T x \quad \text{s.t.} \quad Ax = b, \quad \max_y b^T y \quad \text{s.t.} \quad A^T y \leq c.$$

若原问题可行且有限下确界为 p^* , 则原问题与对偶问题都有最优解, 且两个最优值都等于 p^* 。

证明. 原始可行域 $P = \{x : Ax = b, x \geq 0\}$ 是非空多面体。由引理 4.26, 其目标值集合

$$W = \{c^T x : x \in P\}$$

是 $\mathbb{R}$ 中的非空多面体。集合 W 下有界，且一维多面体包含自己的有限下端点，故 $p^* = \inf W$ 属于 W 。因此存在原始可行点 $\mathbf{x}^*$ 满足 $\mathbf{c}^\top \mathbf{x}^* = p^*$ ，原问题达到其最优值。

对任意 $\varepsilon > 0$ ，系统

$$\mathbf{A}\mathbf{x} = \mathbf{b}, \quad \mathbf{c}^\top \mathbf{x} + s = p^* - \varepsilon, \quad \mathbf{x} \geq \mathbf{0}, s \geq 0$$

不可行，否则会有目标值小于 p^* 的原始可行点。对增广矩阵应用定理 4.27，存在 $(\mathbf{y}_\varepsilon, \gamma_\varepsilon)$ 满足

$$\mathbf{A}^\top \mathbf{y}_\varepsilon + \gamma_\varepsilon \mathbf{c} \geq \mathbf{0}, \quad \gamma_\varepsilon \geq 0, \quad \mathbf{b}^\top \mathbf{y}_\varepsilon + \gamma_\varepsilon (p^* - \varepsilon) < 0.$$

取任一原始可行 $\bar{\mathbf{x}}$ 并与第一式作内积可知 $\gamma_\varepsilon > 0$ ，否则会与最后一式矛盾。令 $\hat{\mathbf{y}}_\varepsilon = -\mathbf{y}_\varepsilon / \gamma_\varepsilon$ ，便有 $\mathbf{A}^\top \hat{\mathbf{y}}_\varepsilon \leq \mathbf{c}$ 且 $\mathbf{b}^\top \hat{\mathbf{y}}_\varepsilon > p^* - \varepsilon$ 。

记对偶可行多面体为 $D = \{\mathbf{y} : \mathbf{A}^\top \mathbf{y} \leq \mathbf{c}\}$ 。上面的构造说明 D 非空，且其目标值集合

$$V = \{\mathbf{b}^\top \mathbf{y} : \mathbf{y} \in D\}$$

对每个 $\varepsilon > 0$ 都包含一个大于 $p^* - \varepsilon$ 的值。弱对偶说明 V 中的每个值都不超过 p^* ，所以 $\sup V = p^*$ 。由引理 4.26， V 是 $\mathbb{R}$ 中的多面体；非空的一维多面体只能是闭区间、闭射线、单点或整条实线。由于 V 有有限上确界，它必包含上端点 p^* 。因此存在 $\mathbf{y}^* \in D$ 使 $\mathbf{b}^\top \mathbf{y}^* = p^*$ ，对偶最优解达到与原问题相同的最优值。 ■

示例 4.29 二维资源分配的原始与对偶证书 考虑

$$\max_{x_1, x_2 \geq 0} 3x_1 + 2x_2 \quad \text{s.t.} \quad 2x_1 + x_2 \leq 4, \quad x_1 + 2x_2 \leq 4.$$

为两类资源设置价格 $u_1, u_2 \geq 0$ 。由于原问题是最大化，对可行点的资源余量按非负价格计价会给出目标上界：

$$\begin{aligned} \mathcal{L}(\mathbf{x}, \mathbf{u}) &= 3x_1 + 2x_2 + u_1(4 - 2x_1 - x_2) + u_2(4 - x_1 - 2x_2) \\ &= 4u_1 + 4u_2 + (3 - 2u_1 - u_2)x_1 + (2 - u_1 - 2u_2)x_2. \end{aligned}$$

要使 $\sup_{\mathbf{x} \geq \mathbf{0}} \mathcal{L}(\mathbf{x}, \mathbf{u})$ 有限， x_1, x_2 的系数必须非正，因而 $2u_1 + u_2 \geq 3$ 且 $u_1 + 2u_2 \geq 2$ 。此时上确界就是 $4u_1 + 4u_2$ ，最小化这个上界得到对偶

$$\min_{u_1, u_2 \geq 0} 4u_1 + 4u_2 \quad \text{s.t.} \quad 2u_1 + u_2 \geq 3, \quad u_1 + 2u_2 \geq 2.$$

原始点 $(x_1, x_2) = (4/3, 4/3)$ 可行, 值为 $20/3$; 对偶点 $(u_1, u_2) = (4/3, 1/3)$ 可行, 值也为 $20/3$ 。弱对偶说明二者同时最优。两项资源约束和两项产品约束均取等号, 互补松弛也逐项成立。

不可行、无界和未达到必须区分。Farkas 向量证明约束不可行; 若原问题沿可行射线无限改善, 弱对偶只说明不存在给出有限下界的对偶候选, 也就是每个允许乘子的对偶函数值都为 $-\infty$, 不能据此断言乘子候选集合为空。在线性规划标准型中, 这种情形表现为对偶不可行。若只有下确界而不达到, 则不能展示原始最优点。一般凸问题还需要额外条件才能保证强对偶。常用的 Slater 条件要求一个留有严格余量的可行点, 但定义 4.2 中的有效定义域可能位于一条直线或一个平面上, 在整个空间里没有内部。所以要先在定义域实际所在的仿射空间中解释“内部”。

定义 4.30 仿射包与相对内部 对非空集合 $C \subseteq \mathbb{R}^d$, 其仿射包 (affine hull) 是全部有限仿射组合 $\sum_i \alpha_i x_i$ 组成的集合, 其中 $x_i \in C, \sum_i \alpha_i = 1$, 权重可为负。点 $x \in C$ 属于相对内部 (relative interior), 是指存在 $r > 0$ 使 $B(x, r) \cap \text{aff } C \subseteq C$ 。

例如平面中的线段没有二维内部, 但在它所在的直线上, 去掉两个端点后就是相对内部。

本章采用如下 Slater 版本。设 f 和不等式函数 g_k 都是适当凸函数, 即它们不恒为 $+\infty$ 、从不取 $-\infty$ 且至少在一点取有限值; 这些函数具有共同凸定义域 D , 等式约束为仿射约束 $A\mathbf{w} = \mathbf{b}$ 。若存在

$$\bar{\mathbf{w}} \in \text{ri } D, \quad A\bar{\mathbf{w}} = \mathbf{b}, \quad g_k(\bar{\mathbf{w}}) < 0 \quad \text{对所有 } k,$$

并且原问题最优值有限, 则原、对偶最优值相等, 且存在最优对偶乘子。证明把可达到的“约束函数值与目标值”集合与严格低于原最优值的点分离; 在等式可达的仿射子空间中进行分离, 可先排除冗余等式产生的法向量。相对内部中的严格可行点排除了目标系数为零的异常分离向量, 归一化后便得到所需乘子。这里列出的定义域、仿射等式和有限最优值都是所采用版本的一部分。凸性本身并不够, 也不能把前面的线性规划证明原样套到任意凸问题。第 15 章会在状态、策略和价值定义后, 把同一对偶工具用于价值函数与占用度量。

这项结论没有补上原始最小值的达到。例如在实线上最小化 e^x , 没有不等式要违反, 最优值为 0 而没有原始最优点。反过来, 某个凸问题即使没有 Slater 点, 找到 KKT 候选仍足以证明它全局最优; Slater 是用于保证乘子存在和零间隙的充分条件, 不是 KKT 充分性证明的必需假设。在预算例 4.19 中, $\tau > 0$ 时可取足够小的两个正坐标使总和严格小于 τ , 因此

Slater 成立；闭域上的强制目标还保证原始解达到。于是该例同时具备可行解、原始达到、零间隙和对偶达到。这四项不能仅凭一个“凸优化问题”名称全部省去核验。

4.4.3.3 乘子更新与原始—对偶求解

KKT 条件能检验最优性，对偶值能给出目标下界，但我们还需要一个计算过程来寻找未知的乘子。把乘子合记为 $\mathbf{y} = (\mathbf{v}, \boldsymbol{\alpha})$ ，允许域为 $Y = \mathbb{R}^m \times \mathbb{R}_+^p$ 。在给定 $\mathbf{y}^{(t)}$ 时先求

$$\begin{aligned}\mathbf{w}^{(t)} &\in \arg \min_{\mathbf{w}} \mathcal{L}(\mathbf{w}, \mathbf{y}^{(t)}), \\ \mathbf{s}^{(t)} &= (\mathbf{a}(\mathbf{w}^{(t)}), \mathbf{g}(\mathbf{w}^{(t)})), \\ \mathbf{y}^{(t+1)} &= \Pi_Y(\mathbf{y}^{(t)} + \eta^{(t)} \mathbf{s}^{(t)}).\end{aligned}$$

等式乘子直接加残差，不等式乘子加残差后逐项截到非负区间。违反预算使价格上升，资源有余量使价格下降；这与原变量沿负梯度更新的方向相反。内层最小值必须达到且有限，否则这一步没有定义。

为什么残差给出了合法方向？对任意 $\mathbf{y}' \in Y$ ，

$$q(\mathbf{y}') \leq \mathcal{L}(\mathbf{w}^{(t)}, \mathbf{y}') = q(\mathbf{y}^{(t)}) + \langle \mathbf{s}^{(t)}, \mathbf{y}' - \mathbf{y}^{(t)} \rangle.$$

所以 q 是凹函数， $\mathbf{s}^{(t)}$ 是其全局仿射上界斜率， $-\mathbf{s}^{(t)} \in \partial(-q)(\mathbf{y}^{(t)})$ 。这正是对凸函数 $-q$ 作投影次梯度下降。若最优乘子 $\mathbf{y}^*$ 存在、 $\|\mathbf{y}^{(0)} - \mathbf{y}^*\|_2 \leq R_y$ ，沿途 $\|\mathbf{s}^{(t)}\|_2 \leq G_y$ ，投影距离不增和前节距离递推给

$$\max_{t < T} q(\mathbf{y}^{(t)}) \geq d^* - \frac{R_y^2 + G_y^2 \sum_{t < T} (\eta^{(t)})^2}{2 \sum_{t < T} \eta^{(t)}}.$$

这个界保证已访问的乘子中至少有一个给出足够好的下界；它不要求每一轮下界都上升，也不保证本轮内层参数满足原始约束。

若 q 可微且 $-q$ 为 L_q 光滑，则用 $\mathbf{y}^{(t+1)} = \Pi_Y(\mathbf{y}^{(t)} + \nabla q(\mathbf{y}^{(t)})/L_q)$ 可回用投影梯度的 $O(1/T)$ 目标差界。一个容易核验的充分设定是内层在固定闭凸域上最小化强凸 f ，所有对偶化约束仿射为 $\mathbf{A}\mathbf{w} - \mathbf{b}$ ，且内层总能达到唯一解。强凸最优性比较给 $\|\mathbf{w}(\mathbf{y}) - \mathbf{w}(\mathbf{y}')\|_2 \leq \|\mathbf{A}\|_2 \|\mathbf{y} - \mathbf{y}'\|_2 / \mu$ ，于是 $\nabla q(\mathbf{y}) = \mathbf{A}\mathbf{w}(\mathbf{y}) - \mathbf{b}$ 且 $L_q \leq \|\mathbf{A}\|_2^2 / \mu$ 。一般非线性约束或多解内层不能直接套用这个光滑常数。

沿预算例取 $\tau = 2$ ，把非负性留在内层可行域，只更新预算乘子 α 。内层解为 $\mathbf{w}(\alpha) = ((2-\alpha)_+, (1-\alpha)_+)^T$ 。在 $0 \leq \alpha \leq 1$ 上，对偶函数为 $q(\alpha) = \alpha - \alpha^2$ ，残差为 $1 - 2\alpha$ 。取 $\alpha^{(0)} = 0$ 、 $\eta = 1/4$ ，则

$$\alpha^{(t)} = \frac{1}{2}(1 - 2^{-t}), \quad \mathbf{w}^{(t)} = \left(\frac{3}{2} + \frac{2^{-t}}{2}, \frac{1}{2} + \frac{2^{-t}}{2} \right)^T, \quad q(\alpha^{(t)}) = \frac{1}{4} - \frac{4^{-t}}{4}.$$

前三轮乘子为 $0, 1/4, 3/8$, 对应内层分配为 $(2, 1), (7/4, 3/4), (13/8, 5/8)$; 预算违反量为 $1, 1/2, 1/4$ 。对偶值趋近 $1/4$ 时, 有限轮的内层候选仍全部超预算。本例从两个坐标各减去一半预算残差即可修复为 $(3/2, 1/2)$, 原目标上界 $U = 1/4$, 与已算下界的间隙为 $4^{-t}/4$ 。修复如此简单依赖本例两个坐标一直为正; 一般问题应单独给出投影或其他可行恢复算法。

即使已经得到最优乘子, 任意内层最小点也未必是原解。在例 4.29 的最优资源价格 $(4/3, 1/3)$ 处, 两个产品的系数同时为零, Lagrangian 对所有非负分配都等于 $20/3$; 内层选 $(10, 10)$ 会超出原预算, 选 $(0, 0)$ 虽可行却不是原始最优。恢复原解还要满足原始约束及互补松弛。对于仿射约束, 步长加权平均的残差等于各轮残差的加权平均, 因此平均常有助于恢复; 是否真的可行及目标是否达标, 仍须用原问题重新检验。内层只近似求解时, 上述上界斜率会带误差, 下一节将说明如何记录这项计算代价。

4.4.3.4 约束变化与解的敏感性

预算例 4.19 也把两类变化分开: 预算改变后, 最优参数怎样移动, 最优目标值又怎样改变。在 $1 < \tau < 3$ 时, $d\mathbf{w}^*/d\tau = (1/2, 1/2)^\top$; 在 $0 < \tau < 1$ 时则为 $(1, 0)^\top$ 。 $\tau = 1$ 处活跃集切换, 解连续但导数改变。最优值为

$$V(\tau) = \begin{cases} 0, & \tau \geq 3, \\ (3 - \tau)^2/4, & 1 \leq \tau \leq 3, \\ ((2 - \tau)^2 + 1)/2, & 0 < \tau \leq 1. \end{cases}$$

在每个活跃集固定的开区间内, $V'(\tau) = -\alpha_{\text{bud}}^*(\tau)$: 放宽一单位预算带来的最优值下降率正是预算乘子的相反数。解导数是向量, 乘子给出的是最优值导数, 二者不能混用。

图 4.5 沿同一个预算轴展示解坐标与乘子。 $\tau = 1$ 时第二个坐标开始离开零边界; $\tau = 3$ 时预算继续增加却不再改善目标。两处切换的条件都需要通过可行性与互补松弛核对, 不能只从曲线是否出现折点判断。

一般地, 设问题依赖参数 τ , 活跃集在邻域内不变, 把驻点条件、等式和活跃约束写成 $\Phi(\mathbf{w}, \mathbf{v}, \boldsymbol{\alpha}, \tau) = \mathbf{0}$ 。若对前三组变量的 Jacobian 矩阵可逆, 则第 3 章的隐式求导给出

$$\frac{d}{d\tau} \begin{bmatrix} \mathbf{w}^* \\ \mathbf{v}^* \\ \boldsymbol{\alpha}^* \end{bmatrix} = - \left(\frac{\partial \Phi}{\partial (\mathbf{w}, \mathbf{v}, \boldsymbol{\alpha})} \right)^{-1} \frac{\partial \Phi}{\partial \tau}.$$

这个 Jacobian 是完整 KKT 系统的导数, 原目标 Hessian 可逆并不足以保证它可逆。活跃集改变或该矩阵奇异时, 解映射可能不可微; 此时不能跨




图 4.5 例 4.19 的解析解。左图为两个最优分配坐标，右图为预算乘子与第二个非负约束的乘子。竖参考线标出 $\tau = 1, 3$ ；在切换点约束可以取等号而乘子为零，说明活跃性与正价格并不等价。

越切换点沿用同一个导数。更具体地，若目标与约束二阶连续可微，活跃约束 Jacobian $\mathbf{A}_I$ 满行秩，则固定活跃集的 KKT 导数为

$$\begin{bmatrix} \nabla_{\mathbf{w}, \mathbf{w}}^2 \mathcal{L} & \mathbf{A}_I^\top \\ \mathbf{A}_I & 0 \end{bmatrix}.$$

若 Lagrangian 的 Hessian 在 $\ker \mathbf{A}_I$ 上正定，该矩阵可逆：齐次方程先给 $\mathbf{A}_I \mathbf{d} = 0$ ，与第一行作内积推出 $\mathbf{d} = 0$ ，满行秩再迫使乘子增量为零。加上活跃不等式乘子严格为正、未活跃约束有严格余量，可在小邻域内保持同一活跃集和局部极小分支。若约束写成 $g_k(\mathbf{w}) - \tau_k \leq 0$ 而目标不直接依赖 τ_k ，对最优值应用链式法则并用 KKT 平衡消去解导数，使得 $\partial V / \partial \tau_k = -\alpha_k^*$ ；目标也依赖参数时，还须加入 $\partial f / \partial \tau_k$ 及其余约束的参数项。

惩罚与硬约束有联系，但不是逐参数自动等价。考虑约束问题

$$\min_{\mathbf{w}} f(\mathbf{w}) \quad \text{s.t.} \quad \|\mathbf{w}\|_1 \leq R.$$

若该问题有原始最优解，强对偶成立，并且对偶最优乘子 λ^* 确实达到，例如满足前述 Slater 条件且最优值有限，则原始最优解同时最小化 $f(\mathbf{w}) + \lambda^* \|\mathbf{w}\|_1$ ；Lagrangian 中的常数 $-\lambda^* R$ 不影响最小点。仅有原、对偶最优值相等并不能保证这样的有限乘子存在。反过来，不同 λ 对应的范数半径可能相同，非凸问题还可能存在对偶间隙。把 $\mathbf{w}$ 写成其他参数的函数也会改变优化几何；即使表示同一预测函数，也不保证产生同一更新轨迹。反向对应也可以精确说明：若 $\hat{\mathbf{w}}$ 最小化 $f + \lambda \|\cdot\|_1$ 且 $\lambda \geq 0$ ，令 $R = \|\hat{\mathbf{w}}\|_1$ ，则它最小化半径为 R 的约束问题，因为任何范数不超过 R 且 f 更低的候选都会使惩罚目标更低。这只构造了与该解匹配的半径，不证明 λ 与 R 一一对应。对一般凸约束，若原始与对偶最优解均达到且对偶间隙为

零, 取 $\rho > \max\{\|\nu^*\|_\infty, \|\alpha^*\|_\infty\}$, 则 $f + \rho(\sum_j |a_j| + \sum_k [g_k]_+)$ 不小于最优 Lagrangian, 并对任何非零约束违反多出严格正量。因此有限参数精确惩罚可由达到的乘子支持。共同二次等式例的 $\nu^* = -16/17$, 故 $\rho > 16/17$ 的绝对值惩罚已经精确, 与二次惩罚只能在极限可行形成对照。

4.5 计算预算有限时的近似优化

前面的方法可能每轮都要读取全部数据、求解一个大问题, 甚至把子问题精确求到最优。当时间或内存不足时, 可以省在哪一步? 放宽候选范围可以简化约束; 用容易求解的上界代替原目标可以简化每轮求解; 只更新一组变量可以缩小子问题; 抽样或近似梯度则减少每轮读取的信息。下面分别分析这些节省计算的办, 同时记录它们增加的误差。

4.5.1 松弛方法

第2章已利用候选范围的包含关系建立松弛界。这里进一步问: 放宽后的集合是否恰好由原候选的加权平均组成? 如果求解器返回一个分数点, 又能否把它改成符合原规则的候选? 例如有两个项目, 要求“至多选择一个”, 候选只有不选、选第一项、选第二项三个点。若暂时允许分数选择, 三个点之间的加权平均也成为候选。把所有这样的平均纳入, 就得到包含原候选的最小凸集。

定义 4.31 有限点集的凸包 设 $S = \{s_1, \dots, s_N\} \subseteq \mathbb{R}^d$ 非空。其凸包 (convex hull) 由这些点的全部凸组合构成:

$$\text{conv}(S) = \left\{ \sum_{i=1}^N \alpha_i s_i : \alpha_i \geq 0, \sum_{i=1}^N \alpha_i = 1 \right\}.$$

例如离散点集

$$S = \{(0, 0), (1, 0), (0, 1)\}$$

可以表示“至多选择一个项目”。把 S 替换为三角形

$$\text{conv}(S) = \{(x_1, x_2) : x_1, x_2 \geq 0, x_1 + x_2 \leq 1\}$$

得到凸松弛 (convex relaxation): 原来的每个候选仍可行, 但增加了分数候选。对最小化问题, 松弛最优值是原最优值的下界; 对最大化问题则是上界。

对于有限非空 S , 精确凸包不改变任意线性目标 $c^T x$ 的最优值: 任意 $x = \sum_i \alpha_i s_i \in \text{conv}(S)$ 都满足 $c^T x = \sum_i \alpha_i c^T s_i \geq \min_{s \in S} c^T s$, 再结合

$S \subseteq \text{conv}(S)$ 即得最小值相等，最大值同理。数值相等仍没有指定求解器返回哪个点：若多个候选都最优，它们的凸组合也最优。

上述三角形中，内部点可以由其他点平均得到，而三个角点不能。这个区别有助于判断连续松弛中是否还保留原来的离散候选。

定义 4.32 凸集的极点 设 $K \subseteq \mathbb{R}^d$ 为凸集。若 $\mathbf{x} \in K$ 满足：对任何 $\mathbf{u}, \mathbf{v} \in K$ 与 $\theta \in (0, 1)$ ，只要 $\mathbf{x} = \theta \mathbf{u} + (1 - \theta) \mathbf{v}$ ，就有 $\mathbf{u} = \mathbf{v} = \mathbf{x}$ ，则称 $\mathbf{x}$ 为 K 的极点 (extreme point)。

极点不能再由其他可行点的非平凡平均得到。线性目标的所有最优点则组成同一个面。

定义 4.33 线性目标的最优面 设线性目标 $\mathbf{c}^\top \mathbf{x}$ 在非空凸集 K 上达到有限最大值 M 。其最优面 (optimal face) 为

$$K^* = \{\mathbf{x} \in K : \mathbf{c}^\top \mathbf{x} = M\}.$$

最小化时，将 M 换为达到的有限最小值即可。

当 $K = \text{conv}(S)$ 且 S 有限时，最优面正是 S 中全部最优点的凸包：若一个凸组合对次优点给了正权重，其线性目标值便严格低于最大值。若 $S \subseteq \mathbb{Z}^d$ ，最优面还含有整数极点。可以在有限个整数最优点中，按坐标次序逐项取最大值，选出一个点。若它是两个可行点的非平凡平均，线性最优性先迫使这两个点都最优，再逐坐标的最大性迫使它们与所选点相同，因此该点确为极点。

即使如此，返回的最优点仍可能是分数点。例如上面的三角形在目标 $x_1 + x_2$ 下，整条边 $x_1 + x_2 = 1$ 都是最优面， $(1/2, 1/2)$ 也最优；逐坐标向上取整却得到不属于原点集的 $(1, 1)$ 。整数极点的存在不保证任意分数最优点都能直接取整。

精确凸包的完整不等式描述可能难以获得。只保留局部约束通常得到更大的多面体，计算较容易而界更松。也可以把乘积 $x_i x_j$ 提升为矩阵变量并要求某个块矩阵半正定，得到半正定松弛；它把原变量与变量乘积之间的部分关系保留在矩阵约束中，代价是需要求解更昂贵的矩阵锥问题。

取整还可能破坏约束。考虑

$$\max_{x_1, x_2 \in \{0, 1\}} x_1 + x_2 \quad \text{s.t.} \quad 2x_1 + 2x_2 \leq 3.$$

整数最优值为 1，而把变量放宽到 $[0, 1]$ 后， $(3/4, 3/4)$ 可行且目标值为 $3/2$ 。逐坐标四舍五入得到 $(1, 1)$ ，却违反容量约束；逐坐标向下取整虽可行，却

得到目标值 0。因此松弛值、恢复可行性的规则和恢复后的目标损失必须分别分析。

若松弛集合比整数可行点的凸包更大，松弛最优值可能严格优于所有整数可行解；这种最优值差异称为整数间隙（integrality gap）。上例采用加法差距时，间隙为 $3/2 - 1 = 1/2$ 。更大的松弛不一定产生严格间隙，它还取决于目标；精确凸包对线性目标没有这种最优值差异，却仍可能包含分数最优点。

图 4.6 固定同一个整数问题，把两种连续可行域并列。精确凸包上的最优值与整数候选一致；局部容量约束定义的松弛多出了整数候选无法平均得到的区域。这一多出的区域，才使目标上界从 1 升到 $3/2$ 。




图 4.6 最大化 $x_1 + x_2$ 的两种放宽。左图精确凸包满足 $x_1 + x_2 \leq 1$ ；右图局部松弛满足 $0 \leq x_i \leq 1$ 与 $x_1 + x_2 \leq 3/2$ 。实心圆为整数可行点，方形为右图的分数最优点 $(3/4, 3/4)$ ，粗边标出各自最优面。两图采用相同坐标尺度。

集合函数的连续扩展也有多种选择。连续变量上的凸性或凹性必须针对所选扩展检验，不能仅凭原集合函数次模就断言成立；扩展方式决定可用的优化工具。第 9 章会讨论一个可精确求解的特殊情形：二值成对能量满足相应次模不等式时，可以表示为非负容量的割。一般集合函数的次模性本身，并不保证任意次模最大化或最小化都能用图割解决。

可计算界构成停止证书。对最小化问题，若可行解给出上界 U ，对偶或松弛给出下界 L ，则

$$0 \leq U - p^* \leq U - L.$$

当 $U = L$ 时已证明全局最优。若把松弛解取整为可行解 $\hat{x}$ ，还应单独分析 $f(\hat{x}) - L$ ；“取整后看起来接近”不是误差界。互补松弛能够证明哪些约束在最优点活跃的 necessary 关系，却不能仅凭约束活跃就反推正乘子，也不总能

直接构造整数解。图模型中的边缘多面体和 MAP 松弛会在图与概率对象建立后复用这里的凸包、上下界和间隙概念。

4.5.2 代理方法

原目标难以直接最小化时，可以先找一个更容易求解的上界。如果上界在当前点恰好等于原目标，那么把上界降到当前值以下，也就把原目标降了下来。梯度下降的二次上界已经展示了这种思路；下面将它推广到其他可求解的替代函数。

定义 4.34 主化代理与 MM 更新 给定目标 $F : C \rightarrow \mathbb{R}$ 、当前点 $\mathbf{w}^{(t)} \in C$ ，主化-最小化方法 (majorization-minimization, MM) 在当前点 $\mathbf{w}^{(t)}$ 构造代理函数 $Q(\mathbf{w} | \mathbf{w}^{(t)})$ ，满足

$$F(\mathbf{w}) \leq Q(\mathbf{w} | \mathbf{w}^{(t)}), \quad F(\mathbf{w}^{(t)}) = Q(\mathbf{w}^{(t)} | \mathbf{w}^{(t)}).$$

上界关系要求对所有 $\mathbf{w} \in C$ 成立。若新点 $\mathbf{w}^{(t+1)} \in C$ 满足代理值不增，就称这一步为 MM 改善更新。

此时

$$\begin{aligned} F(\mathbf{w}^{(t+1)}) &\leq Q(\mathbf{w}^{(t+1)} | \mathbf{w}^{(t)}) \\ &\leq Q(\mathbf{w}^{(t)} | \mathbf{w}^{(t)}) = F(\mathbf{w}^{(t)}). \end{aligned}$$

第一步用全局上界，第二步用代理改善，最后一步用切触条件。若代理只在当前点附近控制原目标，而新点走出该邻域，单调链条便会断裂。

下降引理本身给出一个显式代理。若 F 为 L 光滑，可取

$$Q(\mathbf{w} | \mathbf{w}^{(t)}) = F(\mathbf{w}^{(t)}) + \langle \nabla F(\mathbf{w}^{(t)}), \mathbf{w} - \mathbf{w}^{(t)} \rangle + \frac{L}{2} \|\mathbf{w} - \mathbf{w}^{(t)}\|_2^2.$$

它在当前点切触并全局上界 F ；精确最小化 Q 恰好得到步长 $1/L$ 的梯度更新。仅让代理与原目标在当前点具有相同梯度，却不满足全局上界，不能推出上面的单调不等式链。

例如 $F(x) = x^2/2$ 、当前点 $x^{(t)} = 1$ ，取 $Q(x | 1) = 1/2 + (x-1) + (x-1)^2$ ，则 $Q - F = (x-1)^2/2 \geq 0$ 且当前点取等号。代理最小点为 $1/2$ ，于是 $F(1/2) = 1/8 \leq Q(1/2 | 1) = 1/4 \leq F(1) = 1/2$ 。图 4.7 把这条链与只有相同局部斜率的切线对照。

代理不必精确最小化，但必须分清计算省在何处。记子问题最优值为

$$Q^{*,(t)} = \inf_{\mathbf{w} \in C} Q(\mathbf{w} | \mathbf{w}^{(t)}).$$




图 4.7 代理上界与切线的区别。蓝线为 $F(x) = x^2/2$ ，红线为当前点 1 处的主化代理 Q ，黄虚线为同点切线 $x - 1/2$ 。三者在当前点同值同斜率，但切线位于目标下方，最小化它不能使用 MM 的上界链；红点标出代理最小点对应的值。图为解析教学示例。

若近似子问题解满足

$$Q(\mathbf{w}^{(t+1)} | \mathbf{w}^{(t)}) \leq Q^{\star, (t)} + \epsilon^{(t)},$$

则

$$F(\mathbf{w}^{(t+1)}) \leq F(\mathbf{w}^{(t)}) - \Delta^{(t)} + \epsilon^{(t)},$$

$$\Delta^{(t)} = Q(\mathbf{w}^{(t)} | \mathbf{w}^{(t)}) - Q^{\star, (t)} \geq 0.$$

只有 $\epsilon^{(t)} \leq \Delta^{(t)}$ 才由此保证本轮原目标不增。实际无需知道 $Q^{\star, (t)}$ ，也可直接检查新代理值是否低于旧代理值，再决定接受或继续求解。允许误差超过代理改善时，累计不等式为 $\sum_{t < T} \Delta^{(t)} \leq F(\mathbf{w}^{(0)}) - \inf_C F + \sum_{t < T} \epsilon^{(t)}$ ，其中假设原目标有有限下界。可求和误差控制各轮原目标可能上升的累计幅度，却不自动保证达到全局最优点。

同一数值例中，代理为 $Q(x | 1) = (x - 1/2)^2 + 1/4$ 。若只求到 $x = 3/4$ ，其代理值为 $5/16 < 1/2$ ，原目标为 $9/32$ ，仍严格改善；若返回 $x = 5/4$ ，代理误差为 $9/16 > \Delta^{(t)} = 1/4$ ，原目标反而升为 $25/32$ 。当任务是最大化 F 时，方向相反：构造切触下界 $Q \leq F$ ，使 $Q(\mathbf{w}^{(t+1)} | \mathbf{w}^{(t)}) \geq Q(\mathbf{w}^{(t)} | \mathbf{w}^{(t)})$ ，才有 $F(\mathbf{w}^{(t+1)}) \geq Q(\mathbf{w}^{(t+1)} | \mathbf{w}^{(t)}) \geq F(\mathbf{w}^{(t)})$ 。不能沿用最小化的上界方向。

4.5.3 分块方法

若联合求解所有变量太贵，而固定其中一组后问题变得简单，就可以轮流更新。将变量分成 $\mathbf{u}$ 与 $\mathbf{v}$ 两组，每次固定一组，只求另一组的新值。对

$$\Phi(\mathbf{u}, \mathbf{v}) = \frac{1}{2} \|\mathbf{X}\mathbf{u} + \mathbf{Z}\mathbf{v} - \mathbf{y}\|_2^2 + r(\mathbf{u}) + s(\mathbf{v}),$$

分块坐标法 (block coordinate method) 每次只对一个块走梯度或近端步；交替最小化 (alternating minimization) 则精确或近似求解每个块的条件子问题。若每次子问题确实降低同一个 Φ ，目标值单调不增。精确交替最小化时，这一点直接来自

$$\Phi(\mathbf{u}^{(t+1)}, \mathbf{v}^{(t)}) \leq \Phi(\mathbf{u}^{(t)}, \mathbf{v}^{(t)}), \quad \Phi(\mathbf{u}^{(t+1)}, \mathbf{v}^{(t+1)}) \leq \Phi(\mathbf{u}^{(t+1)}, \mathbf{v}^{(t)}).$$

但非凸情形下仍可能停在局部解或依赖初始化。

一个可复核的耦合二次例子是

$$\Phi(u, v) = \frac{1}{2}(u - v)^2 + \frac{1}{2}(u - 1)^2.$$

固定 v 时的唯一最优解为 $u = (v + 1)/2$ ，固定 u 时的唯一最优解为 $v = u$ 。从 $v^{(0)}$ 出发，一轮交替更新得到 $u^{(t+1)} = (v^{(t)} + 1)/2$ 、 $v^{(t+1)} = u^{(t+1)}$ ，因而 $v^{(t+1)} - 1 = (v^{(t)} - 1)/2$ ，最终到达联合最优解 $(1, 1)$ 。这里的收敛来自这个正定二次目标的特殊结构。换成非凸目标 $(uv - 1)^2$ 并从 $(0, 0)$ 开始时，逐块目标在一块固定为零时没有提供离开零点的理由；若平局规则继续选择零，目标保持为 1，而全局最优值为 0。所以逐块精确和目标单调都不单独保证全局最优。若无约束目标连续可微，一个点对每一块都已精确最优，则各块偏导同时为零，故它是驻点。目标联合凸时，这又足以推出全局最优；仅对各块分别凸则不够。上述 $(uv - 1)^2$ 在另一块固定时都是凸二次函数，仍给出了失败例。对于实际迭代，还须证明它确实收敛到块最优解，而非仅看到目标值收敛。

约束耦合时，可以复制共享变量，再通过一致性约束分解为局部子问题。乘子负责协调副本，这改变了每步计算位置，却没有删除原约束。若局部问题没有被足够准确地求解，或协调步长不满足条件，分解形式本身不保证收敛。具体地，最小化 $r(\mathbf{w}) + s(\mathbf{w})$ 可改写为 $\min_{\mathbf{u}=\mathbf{v}} \{r(\mathbf{u}) + s(\mathbf{v})\}$ 。固定等式乘子 $\boldsymbol{\nu}$ 后，两项 Lagrangian 子问题可独立求解：

$$\begin{aligned} \mathbf{u}^{(t)} &\in \arg \min_{\mathbf{u}} \{r(\mathbf{u}) + \langle \boldsymbol{\nu}^{(t)}, \mathbf{u} \rangle\}, \\ \mathbf{v}^{(t)} &\in \arg \min_{\mathbf{v}} \{s(\mathbf{v}) - \langle \boldsymbol{\nu}^{(t)}, \mathbf{v} \rangle\}, \\ \boldsymbol{\nu}^{(t+1)} &= \boldsymbol{\nu}^{(t)} + \eta^{(t)}(\mathbf{u}^{(t)} - \mathbf{v}^{(t)}). \end{aligned} \tag{4.30}$$

两个子问题各接收自己的函数和当前乘子，分别返回一个变量副本；乘子再根据副本差调整，促使它们满足 $\mathbf{u} = \mathbf{v}$ 。这不是固定其他变量的交替最小化：局部副本可以暂时不一致，所改进的是对偶下界，并不保证原始目标在每轮都下降。若两个子问题适当闭凸且强凸，解总存在，负对偶函数的光滑常数可取 $1/\mu_r + 1/\mu_s$ ，步长据此选择；仅凸时则回用有界残差的对偶次梯度分析。子问题无下界时，这种分解不能直接执行。

取 $r(u) = (u-1)^2/2$ 、 $s(v) = (v+1)^2/2$ ，内层解是 $u = 1 - v$ 、 $v = v - 1$ ，对偶函数 $q(v) = 2v - v^2$ 。令 $v^{(0)} = 0$ 、 $\eta^{(t)} = 1/4$ ，得到 $v^{(t)} = 1 - 2^{-t}$ 、 $u^{(t)} = 2^{-t}$ 、 $v^{(t)} = -2^{-t}$ 。第一轮两个副本各自使局部目标为零，却相差 2；第三次取值为 $1/4, -1/4$ ，差缩小到 $1/2$ 。将二者平均为共同变量 $w = 0$ ，恢复可行上界 $r(0) + s(0) = 1$ ，与 $q(v^{(t)}) = 1 - 4^{-t}$ 之间的差为 4^{-t} 。这里的平均恰好最优来自对称二次结构，不是一般副本问题的免费恢复规则。

若每轮只保证 $\mathcal{L}(\tilde{\mathbf{w}}^{(t)}, \mathbf{y}^{(t)}) \leq q(\mathbf{y}^{(t)}) + \epsilon^{(t)}$ ，将该候选代入另一组乘子会给

$$q(\mathbf{y}') \leq q(\mathbf{y}^{(t)}) + \langle \tilde{\mathbf{s}}^{(t)}, \mathbf{y}' - \mathbf{y}^{(t)} \rangle + \epsilon^{(t)}.$$

于是投影次梯度的单步距离界多出 $2\eta^{(t)}\epsilon^{(t)}$ 。累加后，有限步界的分子应增加

$$2 \sum_{t < T} \eta^{(t)} \epsilon^{(t)}.$$

近似内层值本身大于等于 q ，不能直接冒充原问题下界。有可信子问题误差界时，可用下界为

$$\mathcal{L}(\tilde{\mathbf{w}}^{(t)}, \mathbf{y}^{(t)}) - \epsilon^{(t)}.$$

变量也可以是一个分布 q 。此时“更新分布”仍是在某个可行分布集合上降低同一目标，而非一种脱离优化的概率操作。在有限支持 $\{1, \dots, m\}$ 上，分布变量就是概率单纯形

$$\Delta_m = \{\mathbf{q} \in \mathbb{R}^m : q_i \geq 0, \sum_{i=1}^m q_i = 1\}.$$

归一化、非负性和支持集都是可行约束，更新后必须仍留在这个单纯形中。例如块子问题 $\min_{\mathbf{q} \in \Delta_2} \|\mathbf{q} - (0.8, 0.4)^\top\|_2^2/2$ 的解不是原向量：为使两坐标和为 1，各减去 0.1，得到 $(0.7, 0.3)^\top$ ；非负性仍成立，因此它满足该凸投影问题的最优性条件。EM 与变分方法还需要期望、条件分布和散度。第 10 章“随机变量”和第 11 章建立这些对象后，将复用交替优化与 MM 的单调性核对方式。

4.5.4 近似更新方法

有限和目标

$$F_S(\mathbf{w}) = \frac{1}{n} \sum_{i=1}^n \ell_i(\mathbf{w}) + \frac{\lambda}{2} \|\mathbf{w}\|_2^2$$

的经验损失梯度要读取全部 n 项。这里的抽取先只用有限概率权重理解, $\mathbb{E}_I$ 表示按这些权重求和; 条件期望由第 10 章“随机变量”建立, 随机迭代的收敛分析见第 13.4.1.2 节。若 I 在 $\{1, \dots, n\}$ 上均匀抽取, 则完整目标的随机梯度可取

$$\mathbf{g}_I(\mathbf{w}) = \nabla \ell_I(\mathbf{w}) + \lambda \mathbf{w}, \quad \mathbb{E}_I[\mathbf{g}_I(\mathbf{w})] = \nabla F_S(\mathbf{w}).$$

若按概率 $p_i > 0$ 非均匀抽取, 则应改用

$$\mathbf{g}_I(\mathbf{w}) = \frac{\nabla \ell_I(\mathbf{w})}{np_I} + \lambda \mathbf{w}.$$

正则项梯度 $\lambda \mathbf{w}$ 是确定量, 无需抽样; 小批量只需平均若干经过相应加权的损失梯度, 再加上这项确定梯度。例如 $n = 2$ 、当前位置两项标量梯度为 $2, -1$, 完整损失梯度为 $1/2$ 。若以 $p_1 = 3/4, p_2 = 1/4$ 抽样而不重加权, 均值为 $5/4$, 已经改变更新方向的大小; 使用 $1/(np_I)$ 后, 两种输出为 $4/3, -2$, 均值恢复为 $1/2$ 。

在第 t 轮固定已经得到的历史和当前点, 再按该轮概率求有限加权平均, 记作 $\mathbb{E}^{(t)}$ 。无偏性要求的是这个固定历史后的平均, 不只是对一个与迭代无关的固定点成立。若固定历史后的各抽样梯度独立同分布、无偏, 且均方波动不超过 $(\sigma^{(t)})^2$, 将 b 个样本平均后, 交叉误差项均值为零, 故

$$\mathbb{E}^{(t)} \left\| \frac{1}{b} \sum_{j=1}^b \mathbf{g}_{I_j} - \nabla F_S(\mathbf{w}^{(t)}) \right\|_2^2 \leq \frac{(\sigma^{(t)})^2}{b}.$$

这解释了小批量减少波动但增加信息读取量的取舍; 重复使用同一个样本 b 次没有这一收益。有偏近似可写成 $\mathbf{g}^{(t)} = \nabla F_S(\mathbf{w}^{(t)}) + \mathbf{b}^{(t)} + \boldsymbol{\xi}^{(t)}$, 其中 $\mathbf{b}^{(t)} = \mathbb{E}^{(t)} \mathbf{g}^{(t)} - \nabla F_S(\mathbf{w}^{(t)})$ 、 $\mathbb{E}^{(t)} \boldsymbol{\xi}^{(t)} = 0$ 。增加批量可以降低随机波动, 却不会自动消除平均方向与真实梯度之间的偏差 $\mathbf{b}^{(t)}$ 。这里先逐轮比较抽样结果的有限加权平均; 长期随机收敛仍需后文的条件期望工具。

在概率工具建立前, 可以先分析带确定误差的更新

$$\mathbf{w}^{(t+1)} = \mathbf{w}^{(t)} - \eta^{(t)} (\nabla F(\mathbf{w}^{(t)}) + \mathbf{e}^{(t)}).$$

若 F 为 L 光滑且 $0 < \eta^{(t)} \leq 1/L$, 令 $\mathbf{g} = \nabla F(\mathbf{w}^{(t)})$, 下降引理给出的变化上界为 $-\eta^{(t)}\|\mathbf{g}\|_2^2 - \eta^{(t)}\langle \mathbf{g}, \mathbf{e}^{(t)} \rangle + L(\eta^{(t)})^2\|\mathbf{g} + \mathbf{e}^{(t)}\|_2^2/2$ 。将 $L(\eta^{(t)})^2$ 放宽为 $\eta^{(t)}$ 后, 平方展开的交叉项恰好抵消, 得到

$$F(\mathbf{w}^{(t+1)}) \leq F(\mathbf{w}^{(t)}) - \frac{\eta^{(t)}}{2}\|\nabla F(\mathbf{w}^{(t)})\|_2^2 + \frac{\eta^{(t)}}{2}\|\mathbf{e}^{(t)}\|_2^2.$$

误差项因而必须与所求结论一起累计。固定非零偏差通常只允许迭代接近一个误差邻域; $\sum_t \eta^{(t)}\|\mathbf{e}^{(t)}\|_2^2 < \infty$ 使上述目标下降不等式中的累计误差项有限。仅令 $\eta^{(t)} \rightarrow 0$ 仍不够, 还要核对步长总量是否足以持续纠偏, 以及目标与迭代是否保持稳定。若 $F_{\inf} > -\infty$, 求和得到一个可直接使用的有限预算界:

$$\min_{t < T} \|\nabla F(\mathbf{w}^{(t)})\|_2^2 \leq \frac{2(F(\mathbf{w}^{(0)}) - F_{\inf}) + \sum_{t < T} \eta^{(t)}\|\mathbf{e}^{(t)}\|_2^2}{\sum_{t < T} \eta^{(t)}}. \quad (4.31)$$

步长总和发散且加权平方误差和有限时, 右侧趋零; 结论仍只涉及最佳驻点残差。例如 $F(w) = w^2/2$ 、恒定误差 $e \neq 0$ 与 $0 < \eta < 2$ 给 $w^{(t+1)} = (1 - \eta)w^{(t)} - \eta e$, 最终趋向 $-e$ 而非 0。固定偏差即使很小, 也会留下 $e^2/2$ 的目标差。

若理想更新映射 $T^{(t)}(\mathbf{w}) = \mathbf{w} - \eta^{(t)}\nabla F(\mathbf{w})$ 是 $\rho^{(t)}$ -Lipschitz, 实际轨迹与理想轨迹之差 $\delta^{(t)}$ 满足

$$\delta^{(t+1)} \leq \rho^{(t)}\delta^{(t)} + \eta^{(t)}\|\mathbf{e}^{(t)}\|_2. \quad (4.32)$$

令 $a^{(t)} = \eta^{(t)}\|\mathbf{e}^{(t)}\|_2$, 完整展开为

$$\delta^{(T)} \leq \left(\prod_{j=0}^{T-1} \rho^{(j)} \right) \delta^{(0)} + \sum_{t=0}^{T-1} a^{(t)} \prod_{j=t+1}^{T-1} \rho^{(j)},$$

其中空积为 1。若存在统一 $\bar{\rho} < 1$ 使 $\rho^{(t)} \leq \bar{\rho}$, 旧误差几何衰减; $a^{(t)} \rightarrow 0$ 还保证 $\delta^{(T)} \rightarrow 0$, 而 $a^{(t)} \leq a$ 只能给出极限上界 $a/(1 - \bar{\rho})$ 。证明前一结论时, 可把误差和分成有限的早期项与足够小的尾项: 早期项的传播因子趋零, 尾项由几何级数控制。仅有每个 $\rho^{(t)} < 1$ 不够, 例如 $\rho^{(t)} = 1 - 1/(t+2)^2$ 的前 T 项乘积为 $(T+2)/(2(T+1))$, 趋向 $1/2$ 而非零。

若只有 $\rho^{(t)} \leq 1$, 则 $\delta^{(T)} \leq \delta^{(0)} + \sum_{t < T} a^{(t)}$ 。控制这条轨迹偏差需要一次范数误差和; 平方误差可求和不蕴含它: 取 $\eta^{(t)} = 1$ 、 $\|\mathbf{e}^{(t)}\|_2 = 1/(t+1)$ 即可区分两者。即使一次范数和有限, 也只保证偏差有界, 不保证两条轨迹最终重合。若 $\rho^{(t)} > 1$, 传播因子还可能放大早期扰动; 减小步长同时影响误差注入和理想收敛, 需一起计算。

映射系数也必须由目标条件取得。一般 L 光滑目标只能直接给出 $\rho^{(t)} \leq 1 + \eta^{(t)}L$ 。若 F 还凸，则梯度满足

$$\langle \nabla F(\mathbf{x}) - \nabla F(\mathbf{y}), \mathbf{x} - \mathbf{y} \rangle \geq \frac{1}{L} \|\nabla F(\mathbf{x}) - \nabla F(\mathbf{y})\|_2^2.$$

为证明它，对凸光滑函数 $h_{\mathbf{y}}(\mathbf{z}) = F(\mathbf{z}) - \langle \nabla F(\mathbf{y}), \mathbf{z} \rangle$ 使用下降引理； $\mathbf{y}$ 为其全局最小点，故 $h_{\mathbf{y}}(\mathbf{x}) - h_{\mathbf{y}}(\mathbf{y}) \geq \|\nabla F(\mathbf{x}) - \nabla F(\mathbf{y})\|_2^2 / (2L)$ 。交换 $\mathbf{x}, \mathbf{y}$ 后相加即得所需不等式。再展开两次梯度更新的距离平方，得到

$$\|T^{(t)}(\mathbf{x}) - T^{(t)}(\mathbf{y})\|_2^2 \leq \|\mathbf{x} - \mathbf{y}\|_2^2 - \eta^{(t)}(2/L - \eta^{(t)})\|\nabla F(\mathbf{x}) - \nabla F(\mathbf{y})\|_2^2.$$

因此 $0 \leq \eta^{(t)} \leq 2/L$ 时非扩张。若进一步二阶连续可微且 $\mu \mathbf{I} \leq \nabla^2 F \leq L \mathbf{I}$ ，沿两点线段平均 Hessian 可得 $\rho^{(t)} \leq \max\{|1 - \eta^{(t)}\mu|, |1 - \eta^{(t)}L|\}$ 。固定 $0 < \eta < 2/L$ 才给出统一小于 1 的系数；变步长需检查其乘积而不是只逐项检查。

同一递推可比较只替换一个样本的数据集 S, S' 。若每个样本梯度有界，且两条轨迹在使用相同样本时由收缩映射拉近，只在抽到被替换样本时受到额外扰动，就能控制 $\|\mathbf{w}_S^{(t)} - \mathbf{w}_{S'}^{(t)}\|_2$ 。具体地，设每个样本梯度 L -Lipschitz 且在所访问点范数不超过 G ，暂取 $\lambda = 0$ ，两条迭代使用相同索引 $I^{(t)}$ 。记距离为 $\Delta^{(t)}$ ；若 $I^{(t)}$ 不是被替换的索引，则

$$\Delta^{(t+1)} \leq (1 + \eta^{(t)}L)\Delta^{(t)};$$

若恰好抽到被替换项，则再增加至多 $2\eta^{(t)}G$ 。在凸光滑且步长适当时，共同样本的梯度更新由刚才的证明为非扩张映射，从而去掉前式中的膨胀因子。在均匀抽样且固定历史后，被替换索引出现的权重为 $1/n$ ，故 $\mathbb{E}^{(t)}\Delta^{(t+1)} \leq \Delta^{(t)} + 2\eta^{(t)}G/n$ 。相同初值给 $\mathbb{E}\Delta^{(T)} \leq (2G/n)\sum_{t < T}\eta^{(t)}$ 。若测试损失在比较点之间为 K -Lipschitz，损失差再被 $K\Delta^{(T)}$ 控制；也就是说，从参数距离推到损失差，还需要控制损失对参数变化的敏感程度。这称为 **算法稳定性** (algorithmic stability)：训练集改动一个样本时，输出不会变化太大。上述期望递推的严格表述需要第 10.2.2.1 节的条件期望；随机迭代本身的收敛则还需第 13 章“行动和状态”中的步长、累计噪声与平均动力学条件，不能由算法稳定性直接推出。

缩放损失会等比例缩放梯度，因此学习率不能脱离损失尺度比较。梯度裁剪把过大更新限制在指定半径内，改变了估计量并可能引入偏差。具体地，阈值 $c > 0$ 下令 $\text{clip}_c(\mathbf{g}) = \mathbf{g} \min\{1, c/\|\mathbf{g}\|_2\}$ ，并令零向量仍映为零。前述等概率标量梯度 2, -1 的均值为 1/2，裁剪到 $c = 1$ 后变成 1, -1，均值为零；这展示了偏差怎样产生。对更新式直接减去 $\eta\lambda\mathbf{w}$ 的权重衰减，在普通梯度下降中等价于 ℓ_2 惩罚；使用坐标自适应缩放时，两者通常不再等价。

引理 4.35 非负光滑函数的梯度自界 若 $\ell : \mathbb{R}^d \rightarrow [0, \infty)$ 可微且 L 光滑, 其中 $L > 0$, 则

$$\|\nabla \ell(\mathbf{w})\|_2^2 \leq 2L\ell(\mathbf{w}).$$

证明. 在下降引理中取 $\mathbf{v} = \mathbf{w} - \nabla \ell(\mathbf{w})/L$, 得到

$$\ell(\mathbf{v}) \leq \ell(\mathbf{w}) - \frac{1}{2L}\|\nabla \ell(\mathbf{w})\|_2^2.$$

左侧非负, 移项即得结论。若损失可取负值, 这一步失效; 给函数加常数虽不改变梯度, 却会改变右侧, 所以非负性是实质条件。 ■

给定总预算, 松弛应返回可行恢复与上下界, 代理应核验原目标而非只报子问题收敛, 分块应核验联合驻点或副本一致性, 近似更新应核验误差累计。这些检查可以共用前面的下降和距离递推, 但不能互换输出含义: 距离某条理想轨迹很近, 不代表那条轨迹本身全局最优; 对偶值很高, 也不代表本轮原始候选可行。比较总成本时, 应同时计入试探次数、样本读取、局部子问题和恢复步骤, 而非只比较外层迭代轮数。

4.6 多目标、对抗与双层优化

前面的计算预算改变了怎样求同一个答案; 现在改变的是怎样规定答案。多个指标可以由同一决策共同权衡, 也可以由方向相反的两方竞争, 还可以把一次优化的输出作为另一次评价的输入。权衡需要说明偏好, 竞争需要说明行动次序, 嵌套需要说明内层选解规则; 这些约定不能由某个通用梯度更新替代。

4.6.1 多目标优化

设想一个模型既要降低预测误差, 又要减少计算成本。一个方案误差更小但成本更高, 另一个方案更便宜却更不准确, 单看任一指标都不能决定哪个更好。先保留各指标组成的向量, 再说明何时一个方案可以明确优于另一个。

定义 4.36 支配与 Pareto 最优 设 C 为非空可行集合, 损失向量为

$$\mathbf{f} = (f_1, \dots, f_m) : C \rightarrow \mathbb{R}^m,$$

各分量均要最小化。若 $\mathbf{u}, \mathbf{v} \in C$ 满足所有 i 都有 $f_i(\mathbf{u}) \leq f_i(\mathbf{v})$, 且至少一项严格小于, 就称 $\mathbf{u}$ 支配 (dominate) $\mathbf{v}$ 。不可被任何可行方案支配的点称为 Pareto 最优 (Pareto optimal)。

分量逐项不大于在损失向量上给出偏序；不同参数若产生相同损失向量，仍无法按损失区分。这里的支配是相应的严格比较，不是单一排名。下文先用两个目标说明这种区别。

加权和 $\alpha f_1 + (1 - \alpha)f_2$ 把偏好写成一个标量目标， $\alpha \in [0, 1]$ 。给定权重后，就可按该标量目标的光滑性、凸性及约束选择前面的求解方法。若所有权重严格为正，任何全局最小点都为 Pareto 最优：支配它的候选会使加权目标严格下降，造成矛盾。允许零权重时，只能保证不存在所有分量都严格下降的候选，通常称为弱 Pareto 最优。固定权重后，算法只选择在这组指标折算比例下加权损失最小的方案；非凸 Pareto 前沿的某些点无法由任何固定权重得到。例如三个可行方案的损失向量分别为 $(0, 1)$ 、 $(1, 0)$ 和 $(0.6, 0.6)$ 。第三个方案不被前两个方案支配，所以是 Pareto 最优；但对任意 $\alpha \in [0, 1]$ ，前两个方案的加权损失中至少一个不超过 0.5，严格小于第三个方案的 0.6，故权重和永远不会选择第三个方案。在当前点，方向 $\mathbf{d}$ 若满足

$$\langle \nabla f_1(\mathbf{w}), \mathbf{d} \rangle < 0, \quad \langle \nabla f_2(\mathbf{w}), \mathbf{d} \rangle < 0,$$

就是共同下降方向（common descent direction）。寻找最小范数凸组合 $\alpha \nabla f_1 + (1 - \alpha) \nabla f_2$ 相当于把原点投影到两梯度的线段上。

定理 4.37 无共同下降方向的一阶判定 对可微的 m 个目标，在无约束点 $\mathbf{w}$ 处不存在共同严格下降方向，当且仅当存在 $\alpha_i \geq 0$ 、 $\sum_i \alpha_i = 1$ ，使 $\sum_i \alpha_i \nabla f_i(\mathbf{w}) = \mathbf{0}$ 。

证明. 若这样的凸组合存在，而 $\mathbf{d}$ 使每个内积都为负，则加权和内积也为负，与零向量矛盾。反之，若原点不在梯度集合的凸包中，定理 4.20 给出 $\mathbf{d}$ ，使它与每个梯度的内积具有同一严格符号；必要时取 $-\mathbf{d}$ ，便得到共同严格下降方向。 ■

这个条件只排除局部的一阶共同改善，不保证全局 Pareto 最优；高阶变化或远处方案仍可能同时改善所有目标。例如两个目标都为 $-x^2$ ，在 0 的梯度均为零，任意小的非零移动却使两者同时改善。若目标都凸，零梯度凸组合使相应加权和全局最优，从而保证弱 Pareto 最优；要据此得到前面定义的 Pareto 最优，严格正权重是一条充分条件。零权重不能省略检查，例如 $f_1(x) = 0$ 、 $f_2(x) = x^2$ 在 $x = 1$ 满足该一阶判据，但被 $x = 0$ 支配。

共同下降不只是判据，还能给出具体更新。计算权重子问题

$$\alpha^* \in \arg \min_{\alpha \in \Delta_m} \frac{1}{2} \left\| \sum_{i=1}^m \alpha_i \nabla f_i(\mathbf{w}) \right\|_2^2, \quad \bar{\mathbf{g}} = \sum_i \alpha_i^* \nabla f_i(\mathbf{w}).$$

有限梯度的凸包紧且凸, 故 $\bar{\mathbf{g}}$ 就是原点的唯一投影。投影最优性给 $\langle \bar{\mathbf{g}}, \nabla f_i(\mathbf{w}) - \bar{\mathbf{g}} \rangle \geq 0$ 。若 $\bar{\mathbf{g}} \neq 0$, 取 $\mathbf{d} = -\bar{\mathbf{g}}$ 便有 $\langle \nabla f_i, \mathbf{d} \rangle \leq -\|\bar{\mathbf{g}}\|_2^2$ 对全部 i 成立。每个目标均 L_i 光滑且 $L_i > 0$ 时, 任意 $0 < \eta < 2/\max_i L_i$ 都使 $\mathbf{w}^+ = \mathbf{w} + \eta \mathbf{d}$ 同时降低全部目标; 未知常数时, 可回溯直至所有目标的充分下降检验同时通过。若 $\bar{\mathbf{g}} = 0$, 算法返回的只是上述一阶证书。有约束时还要限制 $\mathbf{d}$ 的可行性, 不能直接使用无约束梯度凸包判据。

例如 $f_1(x, y) = ((x-1)^2 + y^2)/2$, $f_2(x, y) = ((x+1)^2 + y^2)/2$ 。在 $(0, 1)$ 两梯度为 $(-1, 1), (1, 1)$, 最小范数平均为 $(0, 1)$; 步长 1 将点移到 $(0, 0)$, 两项目标都由 1 降为 $1/2$ 。此时梯度为 $(-1, 0), (1, 0)$, 原点已在它们之间, 不能再共同下降。加权标量问题的解为 $(2\alpha - 1, 0)$, 展示了改变权重怎样沿同一条取舍曲线选择答案。

4.6.2 极小极大优化

另一类问题让两个变量方向相反:

$$\min_{\mathbf{w} \in W} \max_{\mathbf{z} \in Z} \phi(\mathbf{w}, \mathbf{z}).$$

外层先选择 $\mathbf{w}$, 内层在看到它后选择使损失最大的 $\mathbf{z}$ 。因此外层实际最小化最坏响应值, 不是让两方分别寻找 ϕ 的普通最小点。倒转次序一般会改变值, 原始问题返回的是应对最坏响应的决策; 若还返回一对互为最优响应的候选, 则需核验下面的鞍点关系。

定义 4.38 极小极大鞍点 设 W, Z 非空, $\phi : W \times Z \rightarrow \mathbb{R}$ 。点 $(\mathbf{w}^*, \mathbf{z}^*) \in W \times Z$ 若对所有 $\mathbf{w} \in W, \mathbf{z} \in Z$ 满足

$$\phi(\mathbf{w}^*, \mathbf{z}) \leq \phi(\mathbf{w}^*, \mathbf{z}^*) \leq \phi(\mathbf{w}, \mathbf{z}^*)$$

就称为极小极大鞍点 (minimax saddle point)。

这里“鞍点”描述两个变量承担相反优化方向时的全局比较关系, 不是第 3.3.3 节中由单个标量函数的驻点和 Hessian 矩阵正负曲率定义的微分鞍点。微分鞍点未必求解某个极小极大问题; 极小极大鞍点位于边界或目标不可微时, 也未必满足驻点与 Hessian 判据。对任意候选对定义

$$P(\mathbf{w}) = \sup_{\mathbf{z} \in Z} \phi(\mathbf{w}, \mathbf{z}), \quad D(\mathbf{z}) = \inf_{\mathbf{w} \in W} \phi(\mathbf{w}, \mathbf{z}).$$

总有 $D(\mathbf{z}) \leq P(\mathbf{w})$, 所以 $P(\mathbf{w}) - D(\mathbf{z}) \geq 0$ 是原始-对偶间隙 (primal-dual gap); 间隙为零时, 该候选对满足鞍点不等式。

本章采用以下有限维极小极大版本：若 W, Z 非空、紧且凸， ϕ 连续，对固定 z 的 $\phi(\cdot, z)$ 为凸函数，对固定 w 的 $\phi(w, \cdot)$ 为凹函数，则

$$\min_{w \in W} \max_{z \in Z} \phi(w, z) = \max_{z \in Z} \min_{w \in W} \phi(w, z),$$

且两侧最值达到。紧致性提供最值的达到，凸凹性允许用分离比较混合候选，连续性保证极限不丢失函数值。

可以用前面的分离工具说明交换为何成立。记左侧值为 v ，任取 $c < v$ 。每个 $w \in W$ 都存在 z 使 $\phi(w, z) > c$ ；连续性与 W 的紧性给出有限个 $z_1, \dots, z_k$ ，使每个 w 至少在其中一项超过 c 。考虑向上封闭的集合

$$U = \{\alpha \in \mathbb{R}^k : \text{存在 } w \in W, \phi(w, z_i) \leq \alpha_i \text{ 对全部 } i\}.$$

各目标关于 w 凸使 U 凸； α 的收敛序列所对应的 w 可取收敛子列，故 U 闭。点 $c\mathbf{1}$ 不属于 U ，严格分离给出 $\langle \alpha, c\mathbf{1} \rangle < \inf_{\alpha \in U} \langle \alpha, \alpha \rangle$ 。向上封闭迫使 $\alpha \geq 0$ ，可归一化为 $\sum_i \alpha_i = 1$ 。于是 $\inf_w \sum_i \alpha_i \phi(w, z_i) > c$ 。令 $\bar{z} = \sum_i \alpha_i z_i \in Z$ ，关于 z 的凹性给 $\phi(w, \bar{z}) \geq \sum_i \alpha_i \phi(w, z_i)$ ，所以右侧极大极小值大于 c 。令 $c \uparrow v$ 再结合弱对偶，即得值相等。连续函数在紧积空间上一致连续，使 P, D 分别连续并达到最值；各取一个达到点就由 $D \leq \phi \leq P$ 得到鞍点。

原始与对偶最优解也可形成这一关系：若零对偶间隙、原始与对偶最优解均达到，则 $\mathcal{L}(w^*, y) \leq \mathcal{L}(w^*, y^*) \leq \mathcal{L}(w, y^*)$ 。这是 Lagrangian 的全局鞍点，不是原目标 f 自身的微分鞍点。鲁棒优化中的 z 表示最坏扰动，对抗训练让扰动方提高损失，多任务协调则可能在权重与模型间形成极小极大结构。若缺少上述条件，两个优化次序可能不同；即使值相等，具体梯度下降-上升仍可能旋转或发散，值的存在定理不等于算法收敛定理。

取 $W = Z = [-1, 1]$ 和 $\phi(x, z) = xz$ ，就能复算这种差别。 $P(x) = |x|$ 、 $D(z) = -|z|$ ，唯一鞍点为 $(0, 0)$ ，候选间隙为 $|x| + |z|$ 。若两方都作普通最小化，会偏好乘积为 -1 的角点，但在该处最大化方立刻有动机反向行动。若取同时下降与上升

$$x^{(t+1)} = x^{(t)} - \eta z^{(t)}, \quad z^{(t+1)} = z^{(t)} + \eta x^{(t)},$$

暂不投影时有 $(x^{(t+1)})^2 + (z^{(t+1)})^2 = (1 + \eta^2)((x^{(t)})^2 + (z^{(t)})^2)$ 。每个非零初值都向外旋转。加上盒投影也不保证收敛： $\eta = 1$ 、初值 $(1, 0)$ 时依次得到 $(1, 1), (0, 1), (-1, 1), (-1, 0), (-1, -1), (0, -1), (1, -1), (1, 0)$ ，此后重复，鞍点间隙始终不小于 1。

一种修正是先试探双方响应，再用试探点的方向更新原点，称为外梯度 (extragradient) 更新。记 $\mathbf{u} = (x, z)^\top$ 、 $\mathbf{F}(\mathbf{u}) = (z, -x)^\top$ 、 $K = W \times Z$ ，每轮计算

$$\bar{\mathbf{u}}^{(t)} = \Pi_K(\mathbf{u}^{(t)} - \eta \mathbf{F}(\mathbf{u}^{(t)})), \quad \mathbf{u}^{(t+1)} = \Pi_K(\mathbf{u}^{(t)} - \eta \mathbf{F}(\bar{\mathbf{u}}^{(t)})).$$

这需要两次方向求值与两次投影。对当前双线性例，在投影未激活时，更新矩阵为 $\begin{bmatrix} 1-\eta^2 & -\eta \\ \eta & 1-\eta^2 \end{bmatrix}$ ，距离平方每步乘以 $1 - \eta^2 + \eta^4 < 1$ ($0 < \eta < 1$)。例如 $\eta = 1/2$ 且 $\|\mathbf{u}^{(0)}\|_2 \leq 1/2$ 时，试探点范数至多 $\sqrt{5}/4 < 1$ ，后续校正点范数递减，所以所有投影确实都不激活；此时上述计算完整证明迭代趋于鞍点，间隙也趋零。这是对该例的可核验改善；一般问题还需梯度映射的单调性和 Lipschitz 条件等分析，不能把“多算一次梯度”本身当作收敛定理。

4.6.3 双层优化

选择正则强度时，不能只看这个数本身好不好：必须先用它训练模型，再评价训练后的模型表现。正则强度是外层决策，训练模型是内层优化，外层评价依赖内层返回的参数。一般地，令外层变量为 θ 。如果内层问题有多个最小点，只写 $\mathbf{w}^*(\theta) \in \arg \min_{\mathbf{w}} L_{\text{in}}(\mathbf{w}, \theta)$ 并不能定义一个单值映射，不同最小点还可能给出不同的外层损失。此时可以分别把最小点集合上的最小、最大外层损失定义为乐观、悲观值，也可以给定由初始化和算法路径决定的单值选择规则。下文假设内层最小解唯一，或已经给定单值选择 S ，并记

$$\mathbf{w}^*(\theta) = S(\theta) \in \arg \min_{\mathbf{w}} L_{\text{in}}(\mathbf{w}, \theta).$$

于是外层目标

$$J(\theta) = L_{\text{out}}(\mathbf{w}^*(\theta), \theta). \quad (4.33)$$

这就是双层优化 (bilevel optimization)。元学习把内层看成任务适应，超参数选择让 θ 控制正则强度或数据权重，定向知识修正则让外层评价修改后的特定行为。例如 $L_{\text{in}}(\mathbf{w}, \theta) = (w^2 - 1)^2$ 的最小点始终为 $\{-1, 1\}$ ，外层取 $L_{\text{out}}(\mathbf{w}, \theta) = (w - \theta)^2/2$ 。在 $\theta = 1$ ，乐观选解的外层值为 0，悲观选解的值为 2。内层最优值相同并不使外层值相同；选择规则还可能随 θ 发生切换。

一种求导方式是把 T 步内层更新全部展开。例如 $\mathbf{w}^{(t+1)} = \mathbf{w}^{(t)} - \eta \nabla_{\mathbf{w}} L_{\text{in}}(\mathbf{w}^{(t)}, \theta)$ ，再按链式法则从 $t = T$ 反向传播。展开法计算的是“运行 T 步以后，输出怎样随外层参数变化”，但存储随 T 增长，且所得梯度对应有有限步内层解，不一定对应精确最优解。

两步展开已经能看清链式结构。设 $\mathbf{w} \in \mathbb{R}^d$ 、 $\theta \in \mathbb{R}^p$ ，固定不依赖 θ 的步长 η ，记 $d \times d$ 和 $d \times p$ 矩阵分别为

$$\mathbf{A}^{(t)} = \mathbf{I} - \eta \nabla_{\mathbf{w}, \mathbf{w}}^2 L_{\text{in}}(\mathbf{w}^{(t)}, \theta), \quad \mathbf{B}^{(t)} = \nabla_{\mathbf{w}, \theta}^2 L_{\text{in}}(\mathbf{w}^{(t)}, \theta).$$

则

$$\frac{d\mathbf{w}^{(t+1)}}{d\theta} = \mathbf{A}^{(t)} \frac{d\mathbf{w}^{(t)}}{d\theta} - \eta \mathbf{B}^{(t)},$$

从而

$$\frac{d\mathbf{w}^{(2)}}{d\theta} = \mathbf{A}^{(1)} \mathbf{A}^{(0)} \frac{d\mathbf{w}^{(0)}}{d\theta} - \eta \mathbf{A}^{(1)} \mathbf{B}^{(0)} - \eta \mathbf{B}^{(1)}.$$

外层梯度再把这个 Jacobian 与 $\nabla_{\mathbf{w}} L_{\text{out}}$ 相乘，并加上外层目标对 θ 的直接偏导。截断某一步会删除相应乘积项，因而改变所求导的算法，而不只是节省存储。若步长或初始化本身依赖外层参数，其导数也必须保留；若更新含不可微投影或离散分支，普通链式法则需要另外检查分支与可微条件。

取 $L_{\text{in}}(\mathbf{w}, \theta) = (\mathbf{w} - \theta)^2/2$ 、 $\mathbf{w}^{(0)} = 0$ 与 $\eta = 1/2$ 。两步得到 $\mathbf{w}^{(1)} = \theta/2$ 、 $\mathbf{w}^{(2)} = 3\theta/4$ ，对应导数为 $1/2, 3/4$ 。为比较有限步与精确求解，外层取 $(\mathbf{w} - 1)^2/2$ ，在 $\theta = 2$ 有 $\mathbf{w}^{(2)} = 3/2$ ，两步外层梯度为 $(3/2 - 1)(3/4) = 3/8$ ；理想内层解 $\mathbf{w}^* = \theta$ 对应梯度却为 $\theta - 1 = 1$ 。两者都算得正确，求导的对象不同。在这个例子中， $\mathbf{w}^{(T)} = (1 - 2^{-T})\theta$ 及其导数都趋向理想分支；一般问题需要额外控制迭代收敛与导数乘积，不能由有限步求导自动得到这个极限。

隐式求导跟踪的是一个选定的非退化局部最小点分支，不自动证明该分支实现全局最小值。只有当这个分支也是全局最小点并符合前述选择规则时，它才与 $\mathbf{w}^*(\theta)$ 及 J 对应。为区分两者，记局部分支及其外层目标为 $\hat{\mathbf{w}}(\theta)$ 和 $\hat{J}(\theta) = L_{\text{out}}(\hat{\mathbf{w}}(\theta), \theta)$ 。若 L_{in} 二阶连续可微，并且

$$\nabla_{\mathbf{w}} L_{\text{in}}(\hat{\mathbf{w}}(\theta), \theta) = \mathbf{0},$$

记在该分支上计算的二阶导数为 $\mathbf{H}_{\mathbf{w}, \mathbf{w}} = \nabla_{\mathbf{w}, \mathbf{w}}^2 L_{\text{in}}$ 和 $\mathbf{H}_{\mathbf{w}, \theta} = \nabla_{\mathbf{w}, \theta}^2 L_{\text{in}}$ 。对驻点方程关于 θ 求导得到

$$\mathbf{H}_{\mathbf{w}, \mathbf{w}} \frac{d\hat{\mathbf{w}}}{d\theta} + \mathbf{H}_{\mathbf{w}, \theta} = \mathbf{0}.$$

当 $\mathbf{H}_{\mathbf{w}, \mathbf{w}}$ 可逆时，第 3 章的隐函数定理给出局部可微分支；固定参数时，这个驻点在附近是孤立的。对非退化局部最小点， $\mathbf{H}_{\mathbf{w}, \mathbf{w}} > \mathbf{0}$ 保证这一可逆性。链式法则于是给出

$$\nabla_{\theta} \hat{J} = \nabla_{\theta} L_{\text{out}} - \mathbf{H}_{\mathbf{w}, \theta}^{\top} \mathbf{H}_{\mathbf{w}, \mathbf{w}}^{-\top} \nabla_{\mathbf{w}} L_{\text{out}}. \quad (4.34)$$

式 (4.34) 是隐式超梯度 (implicit hypergradient)。实际计算通常解线性方程 $\mathbf{H}_{w,w}^\top \mathbf{v} = \nabla_w L_{\text{out}}$, 无须显式求逆。

用二次内层目标可以核对公式。设 $\mathbf{H} > \mathbf{0}$,

$$L_{\text{in}}(\mathbf{w}, \boldsymbol{\theta}) = \frac{1}{2}(\mathbf{w} - \mathbf{B}\boldsymbol{\theta})^\top \mathbf{H}(\mathbf{w} - \mathbf{B}\boldsymbol{\theta}), \quad L_{\text{out}}(\mathbf{w}) = \frac{1}{2}\|\mathbf{C}\mathbf{w} - \mathbf{d}\|_2^2.$$

这里内层最小点唯一, 因此局部分支与全局选择一致: $\hat{\mathbf{w}} = \mathbf{w}^* = \mathbf{B}\boldsymbol{\theta}$ 且 $\hat{J} = J$ 。直接消元给出

$$\nabla_{\boldsymbol{\theta}} J = \mathbf{B}^\top \mathbf{C}^\top (\mathbf{C}\mathbf{B}\boldsymbol{\theta} - \mathbf{d}).$$

隐式公式中 $\mathbf{H}_{w,w} = \mathbf{H}$, $\mathbf{H}_{w,\boldsymbol{\theta}} = -\mathbf{H}\mathbf{B}$, 代入后得到同一结果。计算时若线性方程残差为 $\mathbf{r} = \mathbf{H}^\top \tilde{\mathbf{v}} - \nabla_w L_{\text{out}}$, 解误差为 $\tilde{\mathbf{v}} - \mathbf{v} = \mathbf{H}^{-\top} \mathbf{r}$; 小特征值会放大该误差。因而内层驻点残差、线性求解残差和曲率病态是三种不同的误差来源。

若内层只近似收敛, 驻点残差会进入超梯度误差; 若 Hessian 矩阵奇异, 解映射可能不唯一或不可微; 若内层非凸, 所选局部分支还依赖初始化与算法路径, 并且可能不是全局最小点。后一种情况下, 式 (4.34) 给出的是 $\hat{J}$ 的梯度, 而不是前述全局双层目标 J 的梯度。展开深度、线性方程精度、内层计算预算与解选择规则因此都是问题定义的一部分, 而不只是实现细节。

误差可在局部强凸条件下定量分开。固定 $\boldsymbol{\theta}$, 设近似点 $\tilde{\mathbf{w}}$ 与选定分支 $\hat{\mathbf{w}}$ 之间的凸邻域满足 $\nabla_{w,w}^2 L_{\text{in}} \geq \mu \mathbf{I}$, $\mu > 0$ 。内层残差 $\mathbf{r}_{\text{in}} = \nabla_w L_{\text{in}}(\tilde{\mathbf{w}}, \boldsymbol{\theta})$ 满足

$$\|\tilde{\mathbf{w}} - \hat{\mathbf{w}}\|_2 \leq \frac{\|\mathbf{r}_{\text{in}}\|_2}{\mu},$$

因为梯度沿线段积分后, 与位移的内积至少为 μ 倍距离平方。在近似点计算内层 Hessian $\tilde{\mathbf{H}}$ 、混合导数 $\tilde{\mathbf{B}} = \nabla_{w,\boldsymbol{\theta}}^2 L_{\text{in}}(\tilde{\mathbf{w}}, \boldsymbol{\theta})$ 及外层梯度, 再近似求解伴随方程, 令 $\mathbf{r}_{\text{lin}} = \tilde{\mathbf{H}}^\top \tilde{\mathbf{v}} - \nabla_w L_{\text{out}}(\tilde{\mathbf{w}}, \boldsymbol{\theta})$ 。线性求解单独贡献的超梯度误差至多为 $\|\tilde{\mathbf{B}}\|_2 \|\mathbf{r}_{\text{lin}}\|_2 / \mu$ 。若这些一、二阶导数在该邻域有界且 Lipschitz, 精确线性求解所定义的超梯度表达式作为 $\mathbf{w}$ 的函数有某个有限 Lipschitz 常数 C 。记由近似点与近似伴随解算出的超梯度为 $\widetilde{\nabla_{\boldsymbol{\theta}} J}$, 则总误差满足

$$\|\widetilde{\nabla_{\boldsymbol{\theta}} J} - \nabla_{\boldsymbol{\theta}} \hat{J}\|_2 \leq \frac{C}{\mu} \|\mathbf{r}_{\text{in}}\|_2 + \frac{\|\tilde{\mathbf{B}}\|_2}{\mu} \|\mathbf{r}_{\text{lin}}\|_2. \quad (4.35)$$

右侧第一项来自内层点不够准确, 第二项来自同一点上的线性系统未解准。只压低其中一项不足以控制总误差, 小 μ 也会同时放大二者。取得外层方向后, 可再对选定的外层目标执行梯度或投影更新; 只有所求超梯度对应的目标和误差范围明确, 才能复用前面带误差更新的分析。

4.7 本章小结

最优化需要分别回答四个问题：候选解是否存在，某个点为何最优，算法怎样到达它，以及误差按什么尺度收敛。连续性配合紧致性保证存在；在闭域上，下半连续性与强制性也能通过紧下水平集保证存在。凸性把局部条件提升为全局条件，强凸、光滑性与 PL 条件则分别控制参数距离、单步上界和目标误差。它们不能只用“曲率好”一语合并。

共同二次目标 $(w_1^2 + 16w_2^2)/2$ 展示了这些条件怎样进入计算：统一梯度步受曲率 16 限制，动量改变历史响应，预条件调整两个方向的尺度，牛顿法则直接解曲率方程。它们对同一个无约束答案付出不同的信息与计算成本。加上 ℓ_1 项后，软阈值使尖点可精确处理；加上 $w_1 + w_2 = 1$ 后，二次惩罚的有限参数解仍不满足等式，乘子平衡才给出约束解 (16/17, 1/17)。因此比较方法要固定同一个任务、同一误差要求，并计入各方法实际需要的计算，不能只看更新式是否更复杂或步数是否更少。

带资源约束后，KKT 条件描述目标梯度与约束法向量的平衡，对偶变量提供界和敏感性解释。Farkas 证书把线性约束不可行性写成可检查的不等式，线性规划强对偶再用它证明原始最优值与对偶最优值相等；一般凸问题仍需核验相应条件。松弛、对偶界与可行解共同形成最优性证书；乘子更新提供寻找下界的过程，原解恢复仍需单独保证可行性。预算例中，对偶值持续改善时内层参数仍可能超出预算，这正是不能把求解过程与证书混为一谈的原因。

计算预算不足时，可以组合代理、分块及近似更新，但必须分别说明子问题未解准、变量未协调一致和梯度不准确造成了多大误差。目标下降中的平方误差和，与轨迹偏差中的一次范数和，控制不同对象；副本一致、块最优和联合最优也需要不同条件。多个指标进一步要求约定权重或 Pareto 比较，竞争要求核验最坏响应及鞍点间隙，嵌套要求区分有限步输出、局部驻点分支与理想全局内层解。这些答案都可以“足够好”，但必须说明好在哪个尺度、满足哪些约束、花了多少计算。第 10 章“随机变量”先建立条件期望与噪声工具，第 13 章“行动和状态”再讨论随机逼近的收敛条件；第 15 章“策略的价值与优化”还会复用本章的对偶与鞍点语言。紧邻的第 5 章将把有限维参数推广到函数空间，区分表示存在性、逼近误差与函数类复杂度。

函数空间

拟合一条曲线时，有限维模型常把函数写成固定基函数的线性组合：

$$f_m(x) = \sum_{j=1}^m a_j \phi_j(x). \quad (5.1)$$

当 m 固定时，可以把系数 $(a_1, \dots, a_m)^\top$ 当作普通向量，用欧氏距离比较两个候选解。然而，一旦允许基函数数目增加，系数向量所在的维数也随之改变；同一个函数还可能在不同基下拥有不同的系数。例如 $a + bx$ 换一组基函数后，两个系数的数值可能改变，但各输入上的预测可以完全相同。因此，比较系数不能直接回答两个函数在整个输入范围内相差多少。我们还要问：有限表示能否逼近目标？有限观测又能区分哪些函数变化？

本章直接把函数看成空间中的点。例如 $f(x) = a + bx$ 是一条直线，但作为候选函数，它是由两项系数确定的一个对象； a, b 描述这个候选函数， x 则指定读取函数值的位置。从这个区分出发，需要回答四个问题：怎样比较两个函数在整个输入范围内的差异，怎样在允许的函数中逼近目标，怎样控制读取或变换对近似误差的放大，以及怎样直接寻找最优函数。本章先选择函数空间与误差尺度，再讨论逼近、读取与变换，最后求解函数优化问题。能写出有限表示、算法能找到它、它在未观测输入上仍然准确，是三件各有条件的事。

5.1 函数空间与基本运算

5.1.1 赋范空间与误差度量

设 $\mathcal{X}$ 为输入集合， $\mathbb{R}^{\mathcal{X}}$ 表示从 $\mathcal{X}$ 到 $\mathbb{R}$ 的全部函数。对 $f, g \in \mathbb{R}^{\mathcal{X}}$ 和 $a, b \in \mathbb{R}$ ，定义

$$(af + bg)(x) = af(x) + bg(x), \quad x \in \mathcal{X}.$$

这些逐点运算使 $\mathbb{R}^{\mathcal{X}}$ 成为向量空间。式 (5.1) 描述的集合只是其中由 $\phi_1, \dots, \phi_m$ 张成的有限维子空间。允许无限多个基方向以后，函数仍可

相加和数乘，但必须直接比较函数的大小与差异，不能只比较系数向量的维数。

函数可以相加，并不表示已经知道两个函数相差多少。把误差汇总成一个非负数，还要要求缩放与累加时的误差具有一致规则；例如，函数误差放大两倍时，误差大小也应放大两倍；把两次误差相加，总误差不应超过两者大小之和。范数将这些规则统一写下。

定义 5.1 赋范空间 设 $\mathcal{V}$ 为实向量空间。映射 $\|\cdot\|_{\mathcal{V}} : \mathcal{V} \rightarrow [0, \infty)$ 若对任意 $f, g \in \mathcal{V}$ 和 $a \in \mathbb{R}$ 满足

$$\|f\|_{\mathcal{V}} \geq 0, \quad \|f\|_{\mathcal{V}} = 0 \iff f = 0, \quad \|af\|_{\mathcal{V}} = |a|\|f\|_{\mathcal{V}},$$

以及三角不等式 $\|f+g\|_{\mathcal{V}} \leq \|f\|_{\mathcal{V}} + \|g\|_{\mathcal{V}}$, 则称该映射为范数, $(\mathcal{V}, \|\cdot\|_{\mathcal{V}})$ 称为赋范空间 (normed space)。它诱导距离 $d(f, g) = \|f - g\|_{\mathcal{V}}$ 。

选择不同范数，就是选择不同的误差含义。范数必须为每个空间元素给出有限值；因此，选定积分范数后，还要把不满足相应可积条件的函数排除在空间之外。

例如，紧区间 $[a, b]$ 上的连续函数空间 $C([a, b])$ 常使用一致范数

$$\|f\|_{\infty} = \sup_{x \in [a, b]} |f(x)|.$$

这个范数控制每个输入上的最大误差。若 μ 是一个测度，则第 3 章建立的 $L^p(\mu)$ 空间使用

$$\|f\|_{L^p(\mu)} = \left(\int_{\mathcal{X}} |f(x)|^p d\mu(x) \right)^{1/p}, \quad 1 \leq p < \infty.$$

它控制的是相对于 μ 的整体误差，允许函数在小测度集合上偏离较大。两种误差不能互相替代。这里 L^p 元素按几乎处处相等识别：只在零测集上不同的两个函数是同一个元素，否则积分给出的只是半范数。在 $[0, 1]$ 上令

$$f_n(x) = \max\{1 - nx, 0\},$$

则 $\|f_n\|_{L^2}^2 = 1/(3n) \rightarrow 0$ ，但 $\|f_n\|_{\infty} = 1$ 始终不变。平方积分可以直接复算： $\int_0^{1/n} (1 - nx)^2 dx = 1/(3n)$ 。图 5.1 中峰宽缩小而峰高不变，正好区分了这两种误差。




图 5.1 连续尖峰 $f_n(x) = \max\{1 - nx, 0\}$ 在 L^2 范数下趋于零，原点函数值却始终为 1。峰宽分别为 $1/5$ 和 $1/25$ ；蓝、红线均由解析式生成。平方积分趋于零，并不保证指定位置的函数值也趋于零。

5.1.2 内积空间与正交关系

只知道两个函数的距离，还不足以判断一个近似误差是否与已有表示方向重合。在最小二乘中，最优残差与所有可用方向正交；要在函数空间中使用同样的判断，需要用内积（inner product）判断残差是否沿某个已有方向还可以被减少。

定义 5.2 实内积空间 内积空间（inner-product space）在实向量空间 $\mathcal{V}$ 上配备对称双线性映射 $\langle \cdot, \cdot \rangle_{\mathcal{V}} : \mathcal{V} \times \mathcal{V} \rightarrow \mathbb{R}$ ，并要求 $\langle f, f \rangle_{\mathcal{V}} > 0$ 对每个非零 f 成立。内积诱导范数

$$\|f\|_{\mathcal{V}} = \sqrt{\langle f, f \rangle_{\mathcal{V}}}.$$

要让内积给出的长度成为前面定义范数，还需要证明相加时满足三角不等式。若 $g \neq 0$ ，将 $t = \langle f, g \rangle / \|g\|^2$ 代入 $0 \leq \langle f - tg, f - tg \rangle$ ，得到

$$|\langle f, g \rangle|^2 \leq \|f\|^2 \|g\|^2.$$

$g = 0$ 时也成立。这就是 Cauchy-Schwarz 不等式。再展开 $\|f + g\|^2$ 并用此界，使得 $\|f + g\| \leq \|f\| + \|g\|$ ；其余范数公理直接来自内积公理。这一步只用内积，不要求空间完备。

若 $\langle f, g \rangle = 0$ ，称 f 与 g 正交。长度为 1 且两两正交的一组方向称为正交归一方向；对非零 f, g ，比值 $\langle f, g \rangle / (\|f\| \|g\|)$ 落在 $[-1, 1]$ 内，可以解释

夹角。这里比较的是整个函数，例如在 $[-1, 1]$ 的积分内积下，常函数 1 与函数 x 正交，因为 $\int_{-1}^1 x \, dx = 0$ ，而不是因为它们的图像在平面中垂直。

$L^2(\mu)$ 是基本的内积空间，其内积为

$$\langle f, g \rangle_{L^2(\mu)} = \int_x f(x)g(x) \, d\mu(x).$$

这个积分确实有限，因为 $2|fg| \leq |f|^2 + |g|^2$ ；正定性则使用了几乎处处等价类的约定。但 $L^1(\mu)$ 与一般的 $L^p(\mu)$ 并不都由内积诱导。一个范数来自内积，当且仅当它满足平行四边形恒等式 (parallelogram identity)

$$\|f + g\|^2 + \|f - g\|^2 = 2\|f\|^2 + 2\|g\|^2. \quad (5.2)$$

例如在 $\mathbb{R}^2$ 的 L^1 范数中取 $\mathbf{u} = (1, 0)^\top$ 、 $\mathbf{v} = (0, 1)^\top$ ，左侧为 8，右侧为 4，所以这个范数不可能来自内积。内积展开直接证明了恒等式的必要性。反向判定可用实极化公式 $B(f, g) = (\|f + g\|^2 - \|f - g\|^2)/4$ 恢复内积：平行四边形恒等式给出 $B(f + h, g) + B(f - h, g) = 2B(f, g)$ 。取 $h = f$ 可得 $B(2f, g) = 2B(f, g)$ ，再令 $f = (u + v)/2$ 、 $h = (u - v)/2$ ，使得 $B(u + v, g) = B(u, g) + B(v, g)$ 。加法性先给出有理数齐次性，范数的连续性再把它推广到实数齐次性。结合对称性与 $B(f, f) = \|f\|^2$ ，就得到所需的对称双线性正定内积。内积让我们能够判断正交；增加表示方向时，越来越接近的函数是否有空间内的极限，则要由完备性回答。

5.1.3 Banach 与 Hilbert 空间

下面将累加许多小的函数差，构造柯西列的极限。控制这些差之和时，要用到 L^2 版本的 Minkowski 不等式 (Minkowski inequality)，也就是 L^2 范数的三角不等式。对 $f, g \in L^2(\mu)$ ，Cauchy-Schwarz 不等式给出

$$\begin{aligned} \|f + g\|_{L^2(\mu)}^2 &= \|f\|_{L^2(\mu)}^2 + 2 \int_x f(x)g(x) \, d\mu(x) + \|g\|_{L^2(\mu)}^2 \\ &\leq (\|f\|_{L^2(\mu)} + \|g\|_{L^2(\mu)})^2. \end{aligned}$$

两边开平方得到 $\|f + g\|_{L^2(\mu)} \leq \|f\|_{L^2(\mu)} + \|g\|_{L^2(\mu)}$ ；反复使用即可控制有限个函数之和。

不断增加基函数时，可能得到越来越接近的候选函数，却始终没有一个有限表示等于极限。分析章的完备性在这里要求：这些候选若按所选范数形成柯西序列，空间就应容纳它们的极限。

定义 5.3 Banach 空间 若赋范空间 $\mathcal{V}$ 在诱导距离 $d(f, g) = \|f - g\|_{\mathcal{V}}$ 下完备, 即每个范数柯西序列都在该范数下收敛到 $\mathcal{V}$ 中的元素, 则称其为 Banach 空间 (Banach space)。

完备性不负责证明某个具体序列是柯西序列; 它只保证一旦误差足以让序列内部彼此靠近, 极限不会落到空间之外。

如果既要保证逼近序列的极限仍在空间内, 又要利用正交分解寻找最佳近似, 就需要同时拥有完备性与内积。这两项结构合在一起得到 Hilbert 空间。

定义 5.4 Hilbert 空间 在内积诱导的范数下完备的实内积空间称为 Hilbert 空间 (Hilbert space)。

因此, Hilbert 空间也是 Banach 空间, 但一般 Banach 空间不一定有与原范数相容的内积。“赋范空间加完备性”与“内积空间加完备性”分别得到这两个名称, 不是对同一种结构的两种称呼。

区间 $[a, b]$ 上的 $C([a, b])$ 配备一致范数是 Banach 空间。事实上, 若 (f_n) 在一致范数下为柯西序列, 那么每个 x 处的 $(f_n(x))$ 都是实数柯西序列, 可以定义 $f(x) = \lim_n f_n(x)$ 。柯西条件对所有 x 使用同一个 N , 故 f_n 一致收敛到 f ; 连续函数的一致极限仍连续, 所以 $f \in C([a, b])$ 。

同一个函数集合换一种范数可能失去完备性。连续函数空间 $C([0, 1])$ 配备 L^2 范数就不是完备的。令 $q(x) = \mathbb{I}\{x > 1/2\}$, 对 $n \geq 2$ 取

$$f_n(x) = \begin{cases} 0, & x \leq 1/2, \\ n(x - 1/2), & 1/2 < x < 1/2 + 1/n, \\ 1, & x \geq 1/2 + 1/n. \end{cases}$$

每个 f_n 连续, 且 $\|f_n - q\|_2^2 = 1/(3n)$, 所以 (f_n) 在 L^2 中为柯西列。若连续函数 g 几乎处处等于 q , 连续性迫使 g 在 $(0, 1/2)$ 恒为零、在 $(1/2, 1)$ 恒为一, 因而无法在 $1/2$ 处连续。故这个极限没有任何处处连续的代表元。完成这个空间需要加入可测函数的几乎处处等价类, 得到 $L^2([0, 1])$ 。这里“几乎处处等价”很关键: 如果 f 与 g 只在零测集上不同, 它们在 L^2 中是同一个元素。

$L^2(\mu)$ 本身的完备性可以从柯西列内部构造极限。设 (f_n) 在 $L^2(\mu)$ 中为柯西列。逐次选取子列 (f_{n_k}) , 使

$$\|f_{n_{k+1}} - f_{n_k}\|_{L^2(\mu)} \leq 2^{-k}.$$

令 $h_k = |f_{n_{k+1}} - f_{n_k}|$ 。对有限部分和反复使用上面的 L^2 版 Minkowski 不等式, 再用 Fatou 引理, 可得

$$\int_{\mathcal{X}} \left(\sum_{k=1}^{\infty} h_k \right)^2 d\mu \leq \left(\sum_{k=1}^{\infty} 2^{-k} \right)^2 < \infty.$$

因此 $\sum_k h_k(x)$ 几乎处处有限。在这些点, 相邻子列项的差绝对可求和, 所以 $(f_{n_k}(x))$ 收敛。把它的几乎处处极限记为 f 。同样对尾和使用 Fatou 引理, 得到

$$\|f_{n_\ell} - f\|_{L^2(\mu)} \leq \sum_{k=\ell}^{\infty} 2^{-k} \rightarrow 0.$$

这个极限确实属于 $L^2(\mu)$: 令 $H = \sum_k h_k$, 前面的估计说明 $H \in L^2$, 而 $|f| \leq |f_{n_1}| + H$ 几乎处处成立, 再用三角不等式即可。没有这一步, 仅仅构造出逐点极限还没有得到空间内的极限。原序列是柯西列, 故它与已收敛子列的距离也趋于零, 从而 $f_n \rightarrow f$ 于 $L^2(\mu)$ 。这个论证同时说明为何要把只在零测集上不同的代表元视为同一元素: 构造得到的点态极限本来就只在几乎处处意义下确定。对 $1 \leq p < \infty$ 可用相同的可求和子列思路证明 $L^p(\mu)$ 完备; $p = \infty$ 时则控制本质上确界。因此, $1 \leq p \leq \infty$ 时的 $L^p(\mu)$ 都是 Banach 空间, 而前面已给出的内积使 $L^2(\mu)$ 成为 Hilbert 空间。

无限维还使一些有限维中自动成立的性质需要单独检查。有限维子空间仍然总是闭集, 但一般无限维子空间未必闭; 有限维中的有界序列有收敛子列、线性映射自动连续, 在一般无限维空间中也可能失效。例如, ℓ^2 由数列 $\mathbf{a} = (a_1, a_2, \dots)$ 组成, 要求 $\sum_j a_j^2 < \infty$, 并以平方和的平方根为范数。这个空间中的标准单位向量 $\mathbf{e}_j$ 只有第 j 个坐标为 1, 其余坐标为 0。这些向量都位于单位球内, 但 $j \neq k$ 时

$$\|\mathbf{e}_j - \mathbf{e}_k\|_2 = \sqrt{2}.$$

这个序列没有柯西子列, 因而也没有收敛子列。无限维闭单位球由此给出“闭且有界未必紧”的具体反例; 这里具体指 ℓ^2 的闭单位球。

有限表示可能并未包含极限, 却能任意接近它; 这项逼近性质应与空间的完备性分开。

定义 5.5 稠密子集 设 $(\mathcal{V}, \|\cdot\|)$ 为赋范空间, $\mathcal{F} \subseteq \mathcal{V}$ 。若对每个 $f \in \mathcal{V}$ 和每个 $\varepsilon > 0$, 存在 $g \in \mathcal{F}$ 满足 $\|f - g\| < \varepsilon$, 则称 $\mathcal{F}$ 在 $\mathcal{V}$ 中稠密。等价地, $\mathcal{F}$ 在该范数诱导距离下的闭包等于 $\mathcal{V}$ 。

这里的闭包由原集合及所有能被它任意接近的点组成; 稠密不要求这些点已属于 $\mathcal{F}$ 。完备性与稠密性也不能混为一谈。在刚才的 ℓ^2 空间中, 只有有限个非零坐标的序列构成子空间 c_{00} , 它在 ℓ^2 中稠密却不闭。序列

$(1, 1/2, \dots, 1/n, 0, \dots)$ 属于 c_{00} , 其极限 $(1, 1/2, 1/3, \dots)$ 属于 ℓ^2 但不属于 c_{00} 。这正是闭性在最佳逼近问题中不能省略的原因。有限截断能够不断逼近 ℓ^2 中的元素, 说明 c_{00} 的闭包是 ℓ^2 ; 它并不说明 c_{00} 自身已经包含这些极限。

把缺失的极限补进空间, 称为空间完备化。其构造并不需要先猜出极限是什么函数: 取 $\mathcal{V}$ 中的全部柯西列, 规定 $(f_n) \sim (g_n)$ 当且仅当 $\|f_n - g_n\| \rightarrow 0$ 。等价类 $[(f_n)]$ 代表一个待补入的极限, 逐项相加与数乘定义线性运算, 范数定义为

$$\|[(f_n)]\| = \lim_n \|f_n\|.$$

反三角不等式保证右边存在且与代表无关; 范数为零恰好表示零等价类。原空间通过常数列嵌入, 新空间中的每个元素都能被原空间元素逼近。这里稠密性也可直接验证: 若 $u = [(f_n)]$, 则常数列所代表的 f_k 到 u 的距离为 $\lim_n \|f_k - f_n\|$, 随 $k \rightarrow \infty$ 趋于零。新空间也完备: 对其中的柯西列 (u_k) , 由稠密性选 $v_k \in \mathcal{V}$ 使 $\|v_k - u_k\| < 2^{-k}$, 则 (v_k) 为 $\mathcal{V}$ 中的柯西列, 其等价类 u 满足 $\|u_k - u\| \leq 2^{-k} + \lim_{\ell \rightarrow \infty} \|v_k - v_\ell\| \rightarrow 0$ 。若原空间有内积, 则

$$\langle [(f_n)], [(g_n)] \rangle = \lim_n \langle f_n, g_n \rangle$$

由 Cauchy-Schwarz 和柯西列有界性保证存在、与代表无关, 并延伸原内积。这样内积空间的完备化就是 Hilbert 空间。

闭性是相对于已指定的环境空间而言的; 稠密性问原集合能否接近环境中的每个点; 完备化则把缺少的范数极限加入对象集合。它与分析章的测度完备化不同: 后者将零测集的所有子集也纳入可测集合; 这里补入的则是函数柯西列的极限。此外, 一般 Hilbert 空间不必有可数稠密子集, 不能预先假定它的全部方向都能列成一个序列。

5.1.4 函数空间的选择

有了线性运算、范数、内积与完备性, 还要检查应用需要的操作。例如拟合曲线时, 可能既不希望曲线剧烈振荡, 又要根据观测位置上的函数值判断误差。前一个要求需要控制导数, 后一个要求需要稳定读取点值。Sobolev 空间与再生核空间分别回应这些需求; 它们也可以具备 Banach 或 Hilbert 结构, 这些名称描述的是不同性质。

5.1.4.1 导数控制与 Sobolev 空间

拟合曲线时, 我们可能允许少量尖点, 同时仍希望控制整体变化。例如 $f(x) = |x|$ 只有一个尖点, 却不满足“处处可微”的要求。如果我们关心的是函数及其变化的积分, 能否保留这个函数, 而不必在尖点补出不存在的导数? 办法是改用分部积分恒等式检验导数: 让导数先作用在光滑测试

函数上,再检验能否由另一个普通函数表示结果。测试函数用来探测局部变化,其紧支撑意味着它在靠近区域边界处恒为零,因此不会引入边界项。

定义 5.6 测试函数与局部可积性 设 $U \subseteq \mathbb{R}^d$ 开。函数 φ 的支撑是集合 $\{x \in U : \varphi(x) \neq 0\}$ 在 $\mathbb{R}^d$ 中的闭包。 $C_c^\infty(U)$ 由无限次连续可微、支撑为 U 内紧集的实函数组成。空间 $L_{\text{loc}}^1(U)$ 由对每个紧集 $K \subset U$ 满足 $\int_K |f| < \infty$ 的可测函数的几乎处处等价类组成。

前一项让测试远离边界,后一项让与任何局部测试函数的积分有限;不要求 f 在整个 U 上可积。

定义 5.7 弱导数 设 $U \subseteq \mathbb{R}^d$ 开, $f \in L_{\text{loc}}^1(U)$ 。取多重指标 $\alpha = (\alpha_1, \dots, \alpha_d) \in \mathbb{N}_0^d$, 记 $|\alpha| = \sum_{j=1}^d \alpha_j$, $D^\alpha = \partial_1^{\alpha_1} \dots \partial_d^{\alpha_d}$ 。若存在 $g_\alpha \in L_{\text{loc}}^1(U)$ 使每个 $\varphi \in C_c^\infty(U)$ 都满足

$$\int_U f(x) D^\alpha \varphi(x) dx = (-1)^{|\alpha|} \int_U g_\alpha(x) \varphi(x) dx, \quad (5.3)$$

就称 g_α 为 f 的 α 阶弱导数 (weak derivative), 记为 $D^\alpha f$, 按几乎处处等价理解。

式(5.3)把经典分部积分当作定义;测试函数的紧支撑使边界项消失,因此这个定义本身不需要给 U 另加边界条件。

有了弱导数,就可以同时限制函数值与导数的平方积分。这样不仅控制函数值的整体大小,还限制导数在整个区域上的平方积分,比单用 L^2 范数增加了对变化的约束;它尚未要求每个位置的导数都有同一个上界。

定义 5.8 整数阶平方可积 Sobolev 空间 设 $U \subseteq \mathbb{R}^d$ 为开集, $m \in \mathbb{N}_0$ 。Sobolev 空间

$$W^{m,2}(U) = \{f \in L^2(U) : D^\alpha f \in L^2(U), |\alpha| \leq m\}$$

配备范数

$$\|f\|_{W^{m,2}(U)}^2 = \sum_{|\alpha| \leq m} \|D^\alpha f\|_{L^2(U)}^2. \quad (5.4)$$

其中 $D^0 f = f$, 所有导数均按弱导数理解,元素按几乎处处等价识别。

当 $U = (a, b)$ 为一维区间时, $W^{m,2}(a, b)$ 也常记作 $H^m(a, b)$, 式(5.4)相应写成

$$\|f\|_{H^m(a,b)}^2 = \sum_{r=0}^m \int_a^b |D^r f(x)|^2 dx.$$

这里 $m \in \mathbb{N}_0$, 各阶导数都按上面的弱导数定义理解; 非整数阶 Sobolev 空间需要其他定义, 不由这个有限求和给出。例如一维函数 $f(x) = |x|$ 在 0 点没有经典导数, 但其一阶弱导数几乎处处等于 $\text{sign}(x)$; 在有界区间上, 它仍属于 $W^{1,2}$ 。尖点因而不会自动排除积分意义下的平滑性。

在 $(-1, 1)$ 上把积分分成左右两段, 可以直接核对这一弱导数:

$$\int_{-1}^1 |x| \varphi'(x) dx = \int_{-1}^0 \varphi(x) dx - \int_0^1 \varphi(x) dx = - \int_{-1}^1 \text{sign}(x) \varphi(x) dx.$$

两侧在 0 处的边界项都为零, 原点处任意指定的单个导数值也不会改变积分。图 5.2 将这两条函数并列: 弱导数允许用一个几乎处处确定的函数保存变化信息, 而不要求补出尖点处不存在的经典导数。




图 5.2 $f(x) = |x|$ 与其一阶弱导数 $g(x) = \text{sign}(x)$ 。左图原点为连续尖点; 右图两段分别为 -1 与 1 , 空心端点表示经典导数在原点未定义。

弱导数在原点的代表值可以任取, 积分恒等式不受影响。

几乎处处存在经典导数仍不足以保证该导数就是弱导数。阶跃函数 $h(x) = \mathbb{I}_{\{x > 0\}}$ 几乎处处的经典导数为零, 但 $\int_{-1}^1 h \varphi' = -\varphi(0)$ 一般不为零。若能由某个局部可积函数 g 表示它的弱导数, 取支撑逐渐缩到原点、满足 $0 \leq \varphi_n \leq 1$ 且 $\varphi_n(0) = 1$ 的光滑测试函数, 则 $|\int g \varphi_n| \rightarrow 0$, 却应等于 1, 矛盾。因此跳跃与连续尖点在弱导数意义下也有不同表现; 单凭“只在一个点不可微”, 无法判断函数是否属于相应的 Sobolev 空间。

$W^{m,2}(U)$ 的内积为

$$\langle f, g \rangle_{W^{m,2}} = \sum_{|\alpha| \leq m} \int_U D^\alpha f D^\alpha g.$$

它诱导式 (5.4) 的范数; 其中包含零阶项, 所以非零元素的范数为正。证明完备性时, 取其中的柯西列 (f_n) 。对每个 $|\alpha| \leq m$, 序列 $(D^\alpha f_n)$ 在 $L^2(U)$ 中都是柯西列, 故收敛到某个 $g_\alpha \in L^2(U)$, 其中 g_0 记为 f 。把 f_n 的弱导

数恒等式分别在两侧取极限；Cauchy-Schwarz 不等式保证与固定测试函数的积分连续，于是

$$\int_U f D^\alpha \varphi = (-1)^{|\alpha|} \int_U g_\alpha \varphi.$$

因此 $g_\alpha = D^\alpha f$ ，并且 $f_n \rightarrow f$ 于 $W^{m,2}(U)$ ，所以这个空间确实是 Hilbert 空间。若另外要求边界条件，还须检查可行子空间是否闭。例如定义 $W_0^{m,2}(U) = \overline{C_c^\infty(U)}^{W^{m,2}}$ ，由定义它是闭子空间，因而仍为 Hilbert 空间；在区域边界满足相应光滑性条件时，这才可进一步解释为相应的零边界条件。不能在任意区域上不加说明地把“边界取零”套到几乎处处等价类上。

5.1.4.2 点值控制与再生核空间

实际观测通常给出指定位置上的值。但前面的窄尖峰即使平方积分很小，原点读数仍为 1。若要用函数空间中的近似保证预测值准确，就必须要求：两个函数在空间中越接近，指定位置上的读数也越接近。再生核空间将这项要求直接纳入空间定义。

定义 5.9 再生核 Hilbert 空间 设 $\mathcal{X}$ 为非空集合， $\mathcal{H} \subseteq \mathbb{R}^{\mathcal{X}}$ 是实值函数 Hilbert 空间。若对每个 $x \in \mathcal{X}$ ，存在有限常数 $C_x \geq 0$ ，使

$$|f(x)| \leq C_x \|f\|_{\mathcal{H}} \quad (f \in \mathcal{H}),$$

则称 $\mathcal{H}$ 为再生核 Hilbert 空间 (reproducing kernel Hilbert space, RKHS)。

定义要求空间元素是真正具有确定点值的函数。不同的 x 可以使用不同的有界常数；它并没有要求 $x \mapsto f(x)$ 在某种输入拓扑下连续。把不等式用于 $f - g$ 即可控制读取误差： $|f(x) - g(x)| \leq C_x \|f - g\|_{\mathcal{H}}$ 。这里连续的是“整个函数 f 变动时，读数 $f(x)$ 如何变动”，不等于“固定一个函数，输入 x 变动时，函数值如何变动”。

$L^2([0,1])$ 的元素只有几乎处处意义，一个指定位置的值会随代表函数的选择而变；即使限制为连续函数，图 5.1 也已否定点值的不等式。Sobolev 空间则需要按阶数、维数与区域另行判断。例如在有限区间上， $H^1(a,b)$ 的每个元素有唯一连续的绝对连续代表，其弱导数给出 $f(x) - f(t) = \int_t^x f'(s) ds$ 。令 $\ell = b - a$ ，对 t 平均并用 Cauchy-Schwarz 可得

$$|f(x)| \leq \ell^{-1/2} \|f\|_{L^2} + \ell^{1/2} \|f'\|_{L^2} \leq \sqrt{\ell^{-1} + \ell} \|f\|_{H^1}.$$

这里绝对连续代表的存在也能从弱导数恒等式得到。令 $g = Df$ ， $F(x) = \int_a^x g(s) ds$ ，则 F 绝对连续且弱导数为 g ，故 $u = f - F$ 的弱导数为零。任取

积分为零的 $\eta \in C_c^\infty(a, b)$, 其原函数仍紧支撑, 因而 $\int u\eta = 0$ 。固定积分为一的测试函数 ρ , 把任意 φ 写成 $\varphi - (\int \varphi)\rho + (\int \varphi)\rho$, 得到 $\int u\varphi = c \int \varphi$, 其中 $c = \int u\rho$ 。局部可积函数若与所有光滑紧支撑测试函数的积分均为零, 就几乎处处为零, 所以 $u = c$ 几乎处处。这里所用的区分性质可以在一维直接验证: 对任意内部闭区间, 用取值在 $[0, 1]$ 内的光滑紧支撑函数逼近其示性函数, 由控制收敛知该区间上的积分为零; 因此不定积分在内部处处为常数, 再由 Lebesgue 积分的微积分基本定理得原函数几乎处处为零。这给出 f 的绝对连续代表 $F + c$; 两个连续代表若几乎处处相等, 则处处相等。

因此选取这些连续代表后, $H^1(a, b)$ 可看作 RKHS。维数改变后则可能失败。例如在三维单位球 U 中取 $\varphi \in C_c^\infty(U)$ 且 $\varphi(0) = 1$, 令 $f_n(\mathbf{x}) = \varphi(n\mathbf{x})$, 其中 φ 在 U 外延拓为零。变量替换给出

$$\|f_n\|_{W^{1,2}(U)}^2 = n^{-3}\|\varphi\|_2^2 + n^{-1}\|\nabla\varphi\|_2^2 \longrightarrow 0, \quad f_n(0) = 1.$$

所以即使只检验光滑函数, 也不存在 $|f(0)| \leq C\|f\|_{W^{1,2}(U)}$ 这样的统一界。拥有弱导数不等于能稳定读取点值。

反过来, 稳定点值也不强迫函数关于输入连续。在 $[-1, 1]$ 上固定 $q(x) = \mathbb{I}\{x > 0\}$, 空间 $\{aq : a \in \mathbb{R}\}$ 配内积 $\langle aq, bq \rangle = ab$ 就是一个 RKHS: $|aq(x)| \leq |a|$, 但非零元素有跳跃。名称中的“核”如何出现, 需等到投影与稳定读取的表示建立之后再证明。

5.2 函数空间中的投影与逼近

现在固定目标、允许的函数和误差范数, 问怎样找到一个合适的近似。若候选范围已经固定, 要寻找其中离目标最近的函数; 若可以不断增加表示规模, 要判断误差能否任意小; 若还希望在知道具体目标之前备好有限个近似函数, 则要问: 是否每个候选都接近其中一个代表? 第一种情况固定候选范围, 第二种允许随目标增加表示规模, 第三种要求提前准备有限个代表, 下面分别讨论。

5.2.1 函数投影与最佳近似

5.2.1.1 闭凸投影与最优判据

有限维最小二乘把观测向量投影到设计矩阵的列空间。函数逼近的对应问题是: 给定 Hilbert 空间 $\mathcal{H}$ 中的目标 f 与候选集合 C , 能否找到 $g^* \in C$ 使 $\|f - g^*\|_{\mathcal{H}}$ 最小? 下面的投影定理将说明答案何时存在且唯一。首先需要 C 非空, 才有候选可比较。借助凸性与内积, 可以证明越来越接近最小距离的候选彼此也越来越近, 形成柯西列; 空间完备使它有极限, C 闭再

保证极限仍是允许的函数。凸性还帮助证明最近点唯一，并给出可检查的最优性不等式。

定理 5.10 Hilbert 空间投影定理 设 $\mathcal{H}$ 为实 Hilbert 空间, $C \subseteq \mathcal{H}$ 非空、闭且凸。对每个 $f \in \mathcal{H}$, 存在唯一的 $g^* \in C$ 满足

$$\|f - g^*\|_{\mathcal{H}} = \inf_{g \in C} \|f - g\|_{\mathcal{H}}.$$

这个最近点由变分不等式

$$\langle f - g^*, g - g^* \rangle_{\mathcal{H}} \leq 0, \quad g \in C \quad (5.5)$$

唯一刻画。若 $C = M$ 是闭线性子空间, 则该条件等价于

$$f - g^* \perp M. \quad (5.6)$$

证明. 记 $d = \inf_{g \in C} \|f - g\|_{\mathcal{H}}$, 并取最小化序列 $(g_n) \subseteq C$, 使 $\|f - g_n\|_{\mathcal{H}} \rightarrow d$ 。凸性保证 $(g_n + g_m)/2 \in C$ 。把平行四边形恒等式用于 $f - g_n$ 与 $f - g_m$, 得到

$$\begin{aligned} \|g_n - g_m\|_{\mathcal{H}}^2 &= 2\|f - g_n\|_{\mathcal{H}}^2 + 2\|f - g_m\|_{\mathcal{H}}^2 \\ &\quad - 4\left\|f - \frac{g_n + g_m}{2}\right\|_{\mathcal{H}}^2 \\ &\leq 2\|f - g_n\|_{\mathcal{H}}^2 + 2\|f - g_m\|_{\mathcal{H}}^2 - 4d^2. \end{aligned}$$

右侧随 $m, n \rightarrow \infty$ 趋于 0, 所以 (g_n) 是柯西序列。 $\mathcal{H}$ 完备, 故 $g_n \rightarrow g^* \in \mathcal{H}$; C 闭, 故 $g^* \in C$ 。范数连续给出 $\|f - g^*\|_{\mathcal{H}} = d$, 存在性得证。

若 $g_1, g_2 \in C$ 都达到 d , 同一恒等式给出

$$\|g_1 - g_2\|_{\mathcal{H}}^2 = 2d^2 + 2d^2 - 4\left\|f - \frac{g_1 + g_2}{2}\right\|_{\mathcal{H}}^2 \leq 0,$$

所以 $g_1 = g_2$ 。

再证明刻画。对任意 $g \in C$ 和 $t \in [0, 1]$, 凸性给出 $g^* + t(g - g^*) \in C$ 。最优性意味着

$$\|f - g^*\|_{\mathcal{H}}^2 \leq \|f - g^* - t(g - g^*)\|_{\mathcal{H}}^2.$$

展开右侧、约去公共项并除以 $t > 0$, 得到

$$2\langle f - g^*, g - g^* \rangle_{\mathcal{H}} \leq t\|g - g^*\|_{\mathcal{H}}^2.$$

令 $t \downarrow 0$ 便得到式 (5.5)。反过来, 若该不等式成立, 则对任意 $g \in C$,

$$\|f - g\|_{\mathcal{H}}^2 = \|f - g^*\|_{\mathcal{H}}^2 + \|g - g^*\|_{\mathcal{H}}^2 - 2\langle f - g^*, g - g^* \rangle_{\mathcal{H}} \geq \|f - g^*\|_{\mathcal{H}}^2,$$

所以 g^* 是最近点。

若 $C = M$ 为线性子空间, 则对每个 $h \in M$, 可分别取 $g = g^* + h$ 和 $g = g^* - h$ 。式 (5.5) 同时给出 $\langle f - g^*, h \rangle \leq 0$ 与 $-\langle f - g^*, h \rangle \leq 0$, 故内积为零。反向结论由勾股恒等式直接得到。 ■

闭性不能由“子空间”二字自动获得。以前面的 $c_{00} \subset \ell^2$ 为例, 目标 $\alpha = (1, 1/2, 1/3, \dots)$ 到 c_{00} 的距离下确界为 0, 但 $\alpha \notin c_{00}$, 所以不存在最佳逼近。有限截断可以任意接近目标, 却没有一个有限截断达到距离 0。

5.2.1.2 正交展开与误差分解

只用前几个基函数时, 误差来自哪些未使用的方向? 要逐项读出系数并分解误差, 先选取两两正交、长度为 1 的方向; 要保证增加方向后能恢复整个函数, 还须检查这组方向是否遗漏空间中的某一部分。

定义 5.11 正交归一序列与完备正交系 设 $\mathcal{H}$ 为 Hilbert 空间。序列 $(e_j)_{j \geq 1}$ 若满足 $\langle e_j, e_k \rangle_{\mathcal{H}} = \delta_{j,k}$, 称为正交归一序列。若它的有限线性张成在 $\mathcal{H}$ 中稠密, 则称为完备正交系 (complete orthonormal system)。

有限维时同样使用有限序列; “完备”要求覆盖空间的全部方向。目标 f 在前 m 个方向上的投影为

$$P_m f = \sum_{j=1}^m \langle f, e_j \rangle_{\mathcal{H}} e_j. \quad (5.7)$$

因为 $f - P_m f$ 与每个 e_j 正交, 定理 5.10 说明 $P_m f$ 是 $\text{span}\{e_1, \dots, e_m\}$ 中的唯一最佳逼近。勾股恒等式进一步给出

$$\|f - P_m f\|_{\mathcal{H}}^2 = \|f\|_{\mathcal{H}}^2 - \sum_{j=1}^m |\langle f, e_j \rangle_{\mathcal{H}}|^2. \quad (5.8)$$

左侧非负, 于是得到 Bessel 不等式 $\sum_{j \geq 1} |\langle f, e_j \rangle|^2 \leq \|f\|^2$ 。若正交系完备, 给定 $\varepsilon > 0$, 稠密性给出某个有限线性组合 g 满足 $\|f - g\| < \varepsilon$ 。取 m 包含 g 用到的全部方向, 最佳近似性质给出 $\|f - P_m f\| \leq \|f - g\| < \varepsilon$ 。所以 $P_m f \rightarrow f$, 并得到

$$f = \sum_j \langle f, e_j \rangle e_j, \quad \|f\|^2 = \sum_j |\langle f, e_j \rangle|^2.$$

第二式是 Parseval 等式, 第一式按空间范数收敛, 未额外声称逐点或一致收敛。完备性也等价于“与每个 e_j 正交的向量只能是零”: 令 $M = \overline{\text{span}\{e_j\}}$, 投影定理给出 $f = P_M f + (f - P_M f)$, 余项与每个 e_j 正交; 若此类余项只能为零, 则 $M = \mathcal{H}$ 。Bessel 不等式只保证已选方向的系数可平方求和。要由这些系数恢复 f , 还须排除一个与全部已选方向正交的非零余项。

正交系的完备性与 Hilbert 空间的完备性不是同一性质。前者考察一组给定方向能否稠密张成整个空间, 后者考察任意柯西序列的极限是否仍在空间内。例如 ℓ^2 是完备的 Hilbert 空间, 但只取 $(e_{2j})_{j \geq 1}$ 会遗漏所有奇数坐标方向, 因此这组正交归一向量不是完备正交系。

5.2.1.3 加权投影与误差选择

如果某些输入区域的误差更值得重视, 可以在同一平方误差中改变权重, 而不必改变候选空间。设 w 是 $[-1, 1]$ 上可测、几乎处处为正且属于 $L^1([-1, 1])$ 的权重。在关于测度 $w(x) dx$ 的几乎处处等价类所成空间 $L^2([-1, 1], w(x) dx)$ 上, 定义

$$\langle f, g \rangle_w = \int_{-1}^1 f(x)g(x)w(x) dx.$$

加权平方可积性与 Cauchy-Schwarz 不等式保证该积分对空间中任意 f, g 有限; 权重几乎处处为正则保证它确实定义内积。由于紧区间上的多项式有界, 而 w 可积, 每个多项式都属于这个加权空间, 因此可以对幂函数序列作 Gram-Schmidt 正交化。权重 $w(x) = 1$ 对应 Legendre 多项式; 权重 $w(x) = (1 - x^2)^{-1/2}$ (端点值任取) 对应第一类 Chebyshev 多项式 $T_j(x) = \cos(j \arccos x)$ 。后者在 $x = \pm 1$ 附近赋予更大权重, 因此相同次数的投影优化的是另一种积分误差。

具体地, 给定线性无关的 $\phi_0, \phi_1, \dots$, 依次令

$$q_j = \phi_j - \sum_{k < j} \langle \phi_j, e_k \rangle_w e_k, \quad e_j = q_j / \|q_j\|_w.$$

减去已有方向的投影后, q_j 与这些方向正交; 线性无关保证分母非零。对 $\phi_j(x) = x^j$ 使用该构造就得到归一化的正交多项式。

通常采用 $P_j(1) = T_j(1) = 1$ 的尺度约定, 它们正交但一般并非单位长度。这一约定下, Legendre 多项式满足

$$P_0(x) = 1, \quad P_1(x) = x, \quad (j+1)P_{j+1}(x) = (2j+1)xP_j(x) - jP_{j-1}(x),$$

Chebyshev 多项式满足

$$T_0(x) = 1, \quad T_1(x) = x, \quad T_{j+1}(x) = 2xT_j(x) - T_{j-1}(x).$$

这些递推生成的是相对于各自权重正交的方向，而不是同一组多项式换了名称。

对 $f(x) = x^2$ ，只用 $\text{span}\{1, x\}$ 逼近时，对称权重使一次项系数为零。最佳常数为 $\langle x^2, 1 \rangle_w / \langle 1, 1 \rangle_w$ ：均匀权重给出 $\frac{\int_{-1}^1 x^2 dx}{\int_{-1}^1 dx} = 1/3$ ，Chebyshev 权重经 $x = \cos \theta$ 换元则给出 $\frac{\int_0^\pi \cos^2 \theta d\theta}{\int_0^\pi d\theta} = 1/2$ 。后者更重视两端，而 f 恰在两端较大，故最佳常数也随之增大。

图 5.3 把两条最佳常数放在同一个目标上比较。选择相同的候选空间还不够；权重改变后，“最近”的含义已经改变。不能把一次投影的结果脱离其内积，称为不加限定的最佳逼近。




图 5.3 对 x^2 使用同一候选空间 $\text{span}\{1, x\}$ ，均匀权重的最佳常数为 $1/3$ ，Chebyshev 权重的最佳常数为 $1/2$ 。目标、区间和候选空间保持相同，只改变误差积分的权重。曲线由解析式生成。

区间或权重改变后，正交系数必须随之重算。把 $[a, b]$ 仿射映射到 $[-1, 1]$ 可以迁移 Legendre 或 Chebyshev 基，但 Jacobian 因子和权重也会改变。Chebyshev 多项式还具有适合一致逼近与插值的极值分布；这不意味着其加权 L^2 投影自动就是一致范数下的最佳逼近。投影结论始终相对于所选内积成立，误差度量一旦改变，最佳函数也可能改变。

5.2.2 有限表示与函数逼近

固定定义域、目标集合和误差尺度之后，有限表示可以采取全局多项式、局部片段、非线性单元或可分离因子的形式。下面分别说明怎样构造、误差怎样控制，以及哪些条件不能由“存在一个表示”推出。

5.2.2.1 多项式逼近

下面沿用定义 5.5 的稠密性, 问一个给定目标能否用有限表示达到任意精度。稠密性是一项表示存在性结论: 它允许逼近器依赖目标和精度, 却没有说明需要多少参数、怎样找到逼近器, 或从有限观测能否识别它。

先在 $[0, 1]$ 上取均匀网格 $0, 1/m, \dots, 1$, 利用这些位置的函数值构造一个多项式。对 $f \in C([0, 1])$ 及整数 $m \geq 1$, 得到 Bernstein 多项式

$$(B_m f)(x) = \sum_{j=0}^m f\left(\frac{j}{m}\right) \binom{m}{j} x^j (1-x)^{m-j}. \quad (5.9)$$

权重非负且由二项式定理知其和为 1, 所以 $B_m f(x)$ 是全部网格函数值的加权平均。要让它接近 $f(x)$, 还需证明离 x 很远的网格点所占权重很小。这里的“平均”只是有限非负权重之和; 下面只用第 2 章的二项式恒等式和第 3 章的一致连续性, 不预先调用概率论。

定理 5.12 Bernstein 逼近定理 对每个 $f \in C([0, 1])$,

$$\|B_m f - f\|_\infty \longrightarrow 0.$$

因此, 多项式在 $C([0, 1])$ 的一致范数下稠密。

证明. 连续函数在紧区间上一致连续且有界。记 $M = \|f\|_\infty$ 。给定 $\varepsilon > 0$, 可取 $\delta > 0$ 使 $|u - x| < \delta$ 时 $|f(u) - f(x)| < \varepsilon/2$ 。

对固定 x , 把式(5.9)中的权重记为 $w_{m,j}(x)$ 。由 $j \binom{m}{j} = m \binom{m-1}{j-1}$ 和 $j(j-1) \binom{m}{j} = m(m-1) \binom{m-2}{j-2}$, 有 $\sum_j j w_{m,j} = mx$ 及 $\sum_j j(j-1) w_{m,j} = m(m-1)x^2$ 。这些组合关系分别对 $j \geq 1$ 和 $j \geq 2$ 使用; $m = 1$ 时第二个求和直接为零。将 $j^2 = j(j-1) + j$ 代入并展开平方, 便得

$$\sum_{j=0}^m \left(\frac{j}{m} - x\right)^2 w_{m,j}(x) = \frac{x(1-x)}{m} \leq \frac{1}{4m}.$$

将网格点分为 $|j/m - x| < \delta$ 与 $|j/m - x| \geq \delta$ 两组。近处一组的函数值差小于 $\varepsilon/2$ 。远处一组的总权重满足

$$\sum_{|j/m - x| \geq \delta} w_{m,j}(x) \leq \frac{1}{\delta^2} \sum_{j=0}^m \left(\frac{j}{m} - x\right)^2 w_{m,j}(x) \leq \frac{1}{4m\delta^2}.$$

因此对所有 $x \in [0, 1]$,

$$|B_m f(x) - f(x)| \leq \frac{\varepsilon}{2} + 2M \frac{1}{4m\delta^2}.$$

取 m 足够大使第二项不超过 $\varepsilon/2$, 便得到一致误差不超过 ε 。界对所有 x 使用同一个 m , 所以结论是一致收敛。■

证明把误差分成近处与远处两部分: 一致连续性保证近处网格值与 $f(x)$ 接近, 网格距离的加权平方和则保证远处网格点的总权重很小。如果已知更强的光滑性, 可以得到更具体的误差速率; 只有连续性时, 定理仍给出存在性, 但不承诺对所有连续函数共享一个与目标无关的快速速率。

5.2.2.2 样条逼近

多项式同时调整全域系数, 分段线性样条则把改动限制在少数相邻区间。样条是在每段使用低次多项式、并在结点满足指定衔接条件的函数; 这里使用连续的分段直线。设 $a = x_0 < x_1 < \cdots < x_m = b$, 最大网格宽度为 $h = \max_{0 \leq j < m} (x_{j+1} - x_j)$ 。令 $S_h f$ 在结点处等于 f , 在每个小区间上线性插值, 即对 $x \in [x_j, x_{j+1}]$ 定义

$$(S_h f)(x) = \frac{x_{j+1} - x}{x_{j+1} - x_j} f(x_j) + \frac{x - x_j}{x_{j+1} - x_j} f(x_{j+1}).$$

两个系数非负且和为一, 这就是由端点值计算区间内近似值的具体规则。若 $\omega_f(h) = \sup_{|x-z| \leq h} |f(x) - f(z)|$ 是 f 的连续模, 则

$$\|f - S_h f\|_\infty \leq \omega_f(h).$$

这是因为区间内的插值值是两个端点函数值的凸组合, 每个端点距当前点都不超过 h 。当 f 二阶连续可微时, 插值余项进一步给出

$$\|f - S_h f\|_\infty \leq \frac{h^2}{8} \|f''\|_\infty.$$

常数 $1/8$ 来自每段的几何关系。固定区间内部一点 x , 令 $e = f - S_h f$, 选择 c 使 $q(t) = e(t) - c(t - x_j)(t - x_{j+1})$ 在 x 处也为零。 q 在两个端点及 x 处有三个零点, 两次 Rolle 定理给出某个 ξ 满足 $q''(\xi) = f''(\xi) - 2c = 0$ 。因此 $e(x) = f''(\xi)(x - x_j)(x - x_{j+1})/2$ 。两距离的乘积至多为 $(x_{j+1} - x_j)^2/4$, 便得到上述上界; 端点的插值误差本来就是零。前一个界只依赖连续性, 后一个界额外控制二阶导数, 使误差按网格宽度的平方缩小。在固定结点位置时, 改变一个样条结点的函数值只改变相邻片段, 而改变一个全局多项式系数通常会影响整个区间; 这是局部表示与全局表示的结构差别, 不是两种误差范数之间的优劣结论。为看清“一个局部改动”的范围, 图 5.4 固定同一个中心, 只增加一个单位系数。样条帽函数在相邻结点外严格为零; Bernstein 基在整个开区间内非零; 高斯基 $\phi_c(x) = \exp(-(x - c)^2/(2\sigma^2))$ 虽快速衰减, 仍在所有位置非零。此处它只是显式给定的普通基函数, 不需要再生核理论。局部性需要由基函数的支撑或衰减式判断, 不能由参数个数判断。




图 5.4 单个系数改变对函数的影响。蓝线为 $6x^2(1-x)^2$ ，即四阶 Bernstein 多项式的中心基；红线为中心 $1/2$ 、相邻结点 $1/4, 3/4$ 的线性样条帽；黄线为中心 $1/2$ 、宽度 0.12 的高斯基。系数增量均为 1 ，不另行缩放峰高；图比较作用范围，未比较三种方法的最优逼近误差。

例如 $f(x) = x^2$ 在 $[0, 1]$ 只取结点 $0, 1$ 时，插值为 x ，最大误差 $\max_x (x - x^2) = 1/4$ ，恰好等于 $h^2 \|f''\|_\infty / 8$ 。再加入结点 $1/2$ ，最大网格宽度减半，最大误差成为 $1/16$ 。这里目标固定、网格加密，二阶误差界明确说明了精度怎样随网格变化。

5.2.2.3 神经网络逼近

一维折点目标 $f_\star(x) = |x - 1/2|$ 说明非线性单元怎样改变表示。定义 $\text{ReLU}(t) = \max\{t, 0\}$ ，则

$$f_\star(x) = \text{ReLU}(x - 1/2) + \text{ReLU}(1/2 - x).$$

两个单元的偏置将折点放在 $1/2$ ，输入系数的正负决定折点哪一侧激活。更一般的单隐藏层网络把有限个 $\sigma(\mathbf{w}_j^\top \mathbf{x} + b_j)$ 相加， σ 称为激活函数， b_j 为偏置，单元数 m 称为宽度。网络表示的逼近能力也需要写清激活条件。仅仅“含非线性”还不够：若 $\sigma(t) = t^2$ ，所有单隐藏层有限和仍是次数至多为 2 的多项式，无论增加多少单元都不能得到任意高次目标。下面的结论允许增加宽度，并要求隐藏单元具有偏置。

定理 5.13 单隐藏层的通用逼近 设 $\mathcal{X} \subseteq \mathbb{R}^d$ 为非空紧集, $f: \mathcal{X} \rightarrow \mathbb{R}$ 连续, $\sigma: \mathbb{R} \rightarrow \mathbb{R}$ 连续且不是多项式。对任意 $\varepsilon > 0$, 存在有限宽度 m 、实数 a_j, b_j, c 以及 $\mathbf{w}_j \in \mathbb{R}^d$, 使

$$g(\mathbf{x}) = c + \sum_{j=1}^m a_j \sigma(\mathbf{w}_j^\top \mathbf{x} + b_j), \quad (5.10)$$

$$\sup_{\mathbf{x} \in \mathcal{X}} |g(\mathbf{x}) - f(\mathbf{x})| < \varepsilon.$$

这是 Leshno 等结果在连续激活情形下的表述¹。Sigmoid、Tanh 与 ReLU 都满足激活条件；定理不要求处处可微。连续 S 形激活在两端分别趋于 0 与 1, 是非多项式条件的一个常见特例。特别地, 紧立方体上的有限和

$$g(\mathbf{x}) = \sum_{j=1}^m a_j \sigma(\mathbf{w}_j^\top \mathbf{x} + b_j) \quad (5.11)$$

已能一致逼近连续目标。定理证明涉及更一般的函数空间分离与激活的非多项式性质；本章前面的 Bernstein 证明提供稠密性的完整构造, 折线与 ReLU 的对应则给出一维网络版本的直接构造直觉。

向量值目标可以逐坐标使用结论, 再合并有限个单元。目标含跳跃时, 则不能套用连续目标的一致逼近结论, 因为连续函数的一致极限仍然连续。

不同激活与误差空间还有其他普适逼近版本, 但每个版本都必须重新写清定义域、目标集合和激活条件。它们共同的量词形式是

$$\forall f \forall \varepsilon > 0 \exists \text{网络规模与参数, 使误差小于} \varepsilon.$$

这里先给定 f 和 ε , 再选择宽度与参数, 所以定理不保证某个预先固定的宽度足够。它也没有无条件保证所需网络很小, 参数能由可承受的计算找到, 训练算法会到达该参数, 或者有限样本上的拟合会在新输入上保持准确。多项式的稠密性也有同样边界。表示存在、参数规模、优化可计算性和统计泛化是四个不同问题。

误差范数同样决定结论。若只要求 L^2 误差小, 逼近器可以在小测度区域出现较大尖峰；若要求一致误差小, 则必须同时控制所有输入。若目标定义在非紧域上, 还需要指定加权范数、局部一致收敛或尾部条件。若目标含不连续点, 连续逼近器不可能在整个定义域上一致收敛到目标, 却仍可能在 L^p 意义下逼近。讨论“普适”时必须同时写清目标集合、定义域、逼近器的并集和误差度量。

¹ M. Leshno, V. Y. Lin, A. Pinkus, S. Schocken, *Multilayer Feedforward Networks with a Nonpolynomial Activation Function Can Approximate Any Function In Neural Networks*, 1993, vol. 6, no. 6, pp. 861–867

5.2.2.4 低秩逼近

前面的表示用基函数、局部片段或非线性单元描述一个输入函数。若输入本身分成两组，则可以考虑另一种压缩。例如要记录每个模型在每个查询上的误差，直接存储所有组合可能很大；如果每组对象只需几个数描述，而组合误差由这些数的乘积之和给出，就能用少量因子代替整张表。这就是函数低秩结构要考察的问题。矩阵的秩在此取本科线性代数中的含义，其系统讨论见第6章。设 $p \in \mathcal{P}$ 表示一种预测或模型索引， $q \in \mathcal{Q}$ 表示一种查询、条件或检验索引，量 $E(p, q) \in \mathbb{R}$ 记录二者组合后的函数值或误差。选取有限对象 $p_1, \dots, p_m$ 与 $q_1, \dots, q_n$ ，可组成矩阵

$$\mathbf{E}_{i,j} = E(p_i, q_j).$$

若存在映射 $\mathbf{u} : \mathcal{P} \rightarrow \mathbb{R}^r$ 与 $\mathbf{v} : \mathcal{Q} \rightarrow \mathbb{R}^r$ 使

$$E(p, q) = \langle \mathbf{u}(p), \mathbf{v}(q) \rangle, \quad (5.12)$$

则任意有限矩阵 $\mathbf{E}$ 的秩至多为 r 。也就是说，两组输入之间的组合关系只需要 r 对因子：每一项分别只依赖 p 和 q ，把这些项相加就得到 $E(p, q)$ 。低秩限制独立因子的数量，不要求矩阵元素少。

Cauchy-Schwarz 不等式还把因子尺度传到每个矩阵元素：

$$|E(p, q)| \leq \|\mathbf{u}(p)\|_2 \|\mathbf{v}(q)\|_2.$$

所以秩控制可用方向数，因子范数控制沿这些方向能够产生的幅度。

秩本身只计方向数，不控制数值尺度。若把因子同时变换为 $\mathbf{u}'(p) = c\mathbf{u}(p)$ 和 $\mathbf{v}'(q) = \mathbf{v}(q)/c$ ，其中 $c \neq 0$ ，则式(5.12)不变，单边因子范数却可以任意改变。因此，用低秩结构控制误差或计算时，通常还要固定

$$\sup_{p \in \mathcal{P}} \|\mathbf{u}(p)\|_2 \leq B_u, \quad \sup_{q \in \mathcal{Q}} \|\mathbf{v}(q)\|_2 \leq B_v,$$

或采用对这种缩放更稳定的矩阵范数。方向数 r 与幅度 $B_u B_v$ 承担不同作用。

严格低秩也可能过强。若存在

$$E(p, q) = \langle \mathbf{u}(p), \mathbf{v}(q) \rangle + \eta(p, q), \quad \sup_{p, q} |\eta(p, q)| \leq \delta,$$

则 r 描述结构化主项的方向数， δ 描述剩余表示误差。增大 r 可能减小 δ ，但不会自动给出怎样找到因子、怎样选择查询或怎样由有限观测估计矩阵。代数上的低秩、因子范数、逼近误差、数据访问条件和计算过程仍须分别说明。

例如在 $[-1, 1]^2$ 上取 $E(p, q) = \exp(pq)$, 用 Taylor 有限和得到

$$E_r(p, q) = \sum_{k=0}^{r-1} \frac{p^k q^k}{k!} = \langle \mathbf{u}(p), \mathbf{v}(q) \rangle, \quad u_{k+1}(p) = \frac{p^k}{\sqrt{k!}}, \quad v_{k+1}(q) = \frac{q^k}{\sqrt{k!}}.$$

因为 $|pq| \leq 1$, 余项满足 $\sup_{p,q} |E - E_r| \leq e/r!$, 且两侧因子范数平方都不超过 $\sum_{k=0}^{r-1} 1/k! \leq e$. 这里方向数、因子尺度和一致余项分别得到了控制; 并未声称 r 项是最佳低秩逼近, 也没有从不完整观测中恢复因子。

强化学习中的某些复杂度概念会把模型与分布之间的 Bellman 残差组织成类似矩阵, 再研究其秩或因子化结构。那里的矩阵条目、可实现性、查询协议和样本保证依赖具体决策对象, 必须在相应章节重新定义。仅仅看到某个双线性表达, 既不能直接称其为 Bellman 秩, 也不能推出高效学习。本节提供的是识别这类结构时所需的共同语言。

5.2.3 函数类的有限覆盖

第2章的第2.1节已经建立打散、生长函数与组合维度: 它们考察有限输入上能独立实现哪些输出选择。本节转向函数近似, 问在指定误差范围内, 需要多少个代表函数才能近似整个函数类。模式是否可实现与近似误差有多大, 是两个需要分别说明的问题。

对非空输入空间 $\mathcal{X}$ 上的非空二值函数类 $\mathcal{F} \subseteq \{0, 1\}^{\mathcal{X}}$ 及输入组 $S = (x_1, \dots, x_n)$, 沿用第2章“计数与计算”的限制类记号和定义2.5:

$$\mathcal{F}|_S = \{(f(x_1), \dots, f(x_n)) : f \in \mathcal{F}\}, \quad \Pi_{\mathcal{F}}(n) \text{ 表示该类的生长函数.} \quad (5.13)$$

固定 S 只观察这组输入, 生长函数还要在所有 n 个输入的选择之间取最坏情况。定义2.4与引理2.6提供模式数的组合控制, 但没有为两个函数在整个定义域上的误差选择距离。

例如实线上由 $a \in \mathbb{R}$ 索引的阈值函数类, $f_a(x) = \mathbb{I}\{x \geq a\}$, 在 n 个互异且有序的输入上只能产生 $n+1$ 种模式, 而全部二值函数可以产生 2^n 种模式。但只要 $a \neq b$, 就有 $\sup_{x \in \mathbb{R}} |f_a(x) - f_b(x)| = 1$: 两个阈值之间总有输入使输出不同。在固定 n 个输入上模式有限, 并不说明另一个阈值函数能在所有输入上提供小于1的最坏误差。前一种比较只看固定的有限输入, 后一种要求所有输入上的误差同时小。

有限函数类给出另一个直接的上界。若 $\#\mathcal{F} = M < \infty$, 每个函数在固定输入组上至多贡献一种模式, 因而

$$\Pi_{\mathcal{F}}(n) \leq \min\{M, 2^n\}.$$

例如只含两个常值函数 $f_0(x) = 0$ 与 $f_1(x) = 1$ 的函数类, 在任意非空输入组上恰好产生全零和全一两种模式, 所以 $\Pi_{\mathcal{F}}(n) = 2$ 对所有 $n \geq 1$ 成立。有限类的函数数目限制了模式总数, 但不同函数在某组输入上可能给出相同限制, 因此一般只能得到上界。

实值函数的伪维与胖打散维同样回用“计数与计算”章的第 2.1.2.3 节。伪维检查能否跨过固定阈值, 胖打散维还规定阈值两侧的间隔。函数近似则需要另行规定比较哪些输入、怎样汇总误差: 上确界误差关注最坏位置, 平方积分误差关注测度加权的整体差异。选定这种距离后, 才能用代表函数的数量描述给定精度下的近似规模。

5.2.3.1 函数距离下的覆盖

把候选函数逐个列出可能需要无穷多个对象。如果容许误差不超过 ε , 一组有限代表却可能已经够用。覆盖数记录的是这组代表至少需要多少个, 而不是原类有多少个函数。

定义 5.14 函数类的覆盖数与度量熵 设 $\mathcal{F}$ 为非空函数类, d 为定义 3.4 中的伪距离; 只看有限输入时, 两个不同函数的样本距离可能为零。给定正半径 $\varepsilon > 0$, 若有限集合 $\mathcal{C} \subseteq \mathcal{F}$ 满足: 对每个 $f \in \mathcal{F}$, 存在 $g \in \mathcal{C}$ 使 $d(f, g) \leq \varepsilon$, 则 $\mathcal{C}$ 称为 ε -覆盖。最小覆盖大小记为

$$N(\varepsilon, \mathcal{F}, d),$$

若不存在有限 ε -覆盖, 约定 $N = +\infty$; 其对数称为度量熵。零半径的覆盖也沿用上述约定, 用于下文 $L = 0$ 时的复合函数类。覆盖数回答的是: 在指定误差尺度下, 需要多少个代表函数才能近似整个函数类。

无穷函数类在正尺度下仍可能有有限覆盖; 缩小容许误差时, 覆盖数只能不减。覆盖球可以互相重叠, 也可以伸到函数类之外, 但这里的球心必须属于 $\mathcal{F}$ 。

稠密逼近与有限覆盖的量词次序不同。表示族 $\mathcal{A}$ 在 $\mathcal{V}$ 中稠密说的是 $\forall f \in \mathcal{V} \forall \varepsilon > 0 \exists g \in \mathcal{A}$ 满足误差要求; 类 $\mathcal{F}$ 在每个正尺度有有限覆盖则说的是

$$\forall \varepsilon > 0 \exists \text{有限 } \mathcal{C} \subseteq \mathcal{F} \forall f \in \mathcal{F} \exists g \in \mathcal{C} : d(f, g) \leq \varepsilon.$$

后者必须在知道具体目标之前准备有限个代表, 称为全有界性。即使函数类的范数有统一上界, 也未必做得到: ℓ^2 闭单位球含有两两相距 $\sqrt{2}$ 的 (e_j) , 半径 $\varepsilon < \sqrt{2}/2$ 的球最多包含其中一个, 所以没有有限覆盖。 c_{00} 的稠密性没有消除这个障碍。

距离的选择会改变覆盖对象。常见的 d_∞ 用于有界实函数类, $d_{L^2(\mu)}$ 用于同一测度 μ 下的平方可积函数类, 而样本距离 d_S 取非空输入组 $S = (x_1, \dots, x_n)$ 、 $n \geq 1$; 这些条件保证下列距离有限:

$$\begin{aligned} d_\infty(f, g) &= \sup_{x \in \mathcal{X}} |f(x) - g(x)|, \\ d_{L^2(\mu)}(f, g) &= \left(\int_{\mathcal{X}} |f(x) - g(x)|^2 d\mu(x) \right)^{1/2}, \\ d_S(f, g) &= \left(\frac{1}{n} \sum_{i=1}^n |f(x_i) - g(x_i)|^2 \right)^{1/2}. \end{aligned}$$

d_∞ 同时控制所有输入, $d_{L^2(\mu)}$ 只控制测度 μ 加权的整体差异, d_S 只看给定有限输入。一个样本距离下很小的覆盖未必控制样本外的函数差异; 一个 $L^2(\mu)$ 覆盖也未必控制 μ 几乎不赋质量的区域。第10章建立随机变量后, 才会讨论怎样把这些确定性覆盖结构接到同时误差概率界。

有限输入上的量化给出一个可以直接核对的覆盖。给定 $\varepsilon > 0$, 设每个 $f \in \mathcal{F}$ 在 $S = (x_1, \dots, x_n)$ 上都取值于 $[-B, B]$ 。把该区间分成长度不超过 ε 的小区间, 并对每个被 $\mathcal{F}|_S$ 占据的 n 维网格单元选取一个代表函数。落在同一单元的两个函数在每个 x_i 处相差不超过 ε , 因而其 d_S 距离也不超过 ε 。由此得到

$$N(\varepsilon, \mathcal{F}, d_S) \leq \left(1 + \left\lceil \frac{2B}{\varepsilon} \right\rceil \right)^n.$$

这个界同时写出了值域 $[-B, B]$ 、分辨率 ε 和输入数 n 。它只覆盖 S 上可见的取值向量, 不控制其他输入, 也不声称该上界达到最小覆盖大小。

图 5.5 把量化的含义放到一个可精确计算的函数族中。令 $f_{a,b}(x) = a + bx$, $a, b \in [-1, 1]$, 并取 $S = (-1, 1)$, 则

$$d_S(f_{a,b}, f_{a',b'})^2 = \frac{1}{2}((\Delta a - \Delta b)^2 + (\Delta a + \Delta b)^2) = (\Delta a)^2 + (\Delta b)^2.$$

因此样本距离恰是系数平面中的欧氏距离。把每个坐标分成三个等宽区间, 取九个格心, 就得到半径 $\sqrt{2}/3$ 的覆盖: 任意函数与其格心代表的两项系数差均不超过 $1/3$ 。这证明 $N(\sqrt{2}/3, \mathcal{F}, d_S) \leq 9$, 没有证明九个是最少数量。




图 5.5 仿射函数族的有限覆盖。方形表示 $a, b \in [-1, 1]$ ，九个实心点是类内代表，圆的半径为 $\sqrt{2}/3$ 。每个小方格都被对应格心的闭球覆盖；圆的重叠与越出方形的部分均不影响覆盖要求。

覆盖结构还可以由函数类运算传播。若 $\mathcal{F}$ 与 $\mathcal{G}$ 在同一上确界距离下分别有 ε_F 与 ε_G 覆盖，则

$$\mathcal{F} + \mathcal{G} = \{f + g : f \in \mathcal{F}, g \in \mathcal{G}\}$$

有半径 $\varepsilon_F + \varepsilon_G$ 、大小至多为两个覆盖大小乘积的覆盖。若 $\varphi : \mathbb{R} \rightarrow \mathbb{R}$ 是 L -Lipschitz 函数，则把 $\mathcal{F}$ 的 ε -覆盖逐点送入 φ ，得到 $\varphi \circ \mathcal{F}$ 的 $L\varepsilon$ -覆盖。前一项由 $\|(f + g) - (\tilde{f} + \tilde{g})\|_\infty \leq \|f - \tilde{f}\|_\infty + \|g - \tilde{g}\|_\infty$ 保证，后一项由 $\|\varphi \circ f - \varphi \circ \tilde{f}\|_\infty \leq L\|f - \tilde{f}\|_\infty$ 保证；构造出的中心仍属于相应的新函数类。当 $L = 0$ 时，复合类只含同一个常函数，一个中心就是零半径覆盖。这些关系说明相加或复合以后，需要怎样调整代表函数的数量和允许误差，却自动给出有限样本泛化结论。

覆盖数随距离与误差半径改变，组合维度则随输出区分规则改变。二者都需要明确函数类与输入对象；把计数界或覆盖界用于学习保证时，还要另加抽样和概率条件。

5.2.3.2 查询树上的覆盖

固定输入距离把 $x_1, \dots, x_n$ 预先固定。序贯问题允许第 t 个输入根据此前反馈变化，单个输入序列因而不能列出所有可能路径。这里用二叉树表达分支，并以 $\varepsilon_t \in \{-1, 1\}$ 标记第 t 步选择的分支； ε_t 只是抽象路径标签，不必

等于实值函数输出 $f(\mathbf{x}_t)$ 。若具体问题的反馈不是二元值，还需另行给出编码规则或改用相应的分支集合。

定义 5.15 二叉查询树 设 $\mathcal{X}$ 为非空输入集合， $T \geq 1$ 为整数。深度为 T 的查询树 (query tree) 由映射

$$\mathbf{x}_t : \{-1, 1\}^{t-1} \rightarrow \mathcal{X}, \quad t = 1, \dots, T,$$

组成。这里 $\{-1, 1\}^0$ 只有空路径，根节点因而是一个固定输入 $\mathbf{x}_1$ ；在路径 $\epsilon = (\epsilon_1, \dots, \epsilon_T)$ 上，第 t 步访问 $\mathbf{x}_t(\epsilon_1, \dots, \epsilon_{t-1})$ 。同一个函数 f 沿该路径产生

$$(f(\mathbf{x}_1), f(\mathbf{x}_2(\epsilon_1)), \dots, f(\mathbf{x}_T(\epsilon_1, \dots, \epsilon_{T-1}))).$$

这棵树记录的是一套确定的输入选择规则：每一种过去分支都对应一个下一次查询。它把这套规则可能产生的所有路径一起列出，但没有给路径指定概率。

图 5.6 只展开两层，便能看见这一信息约束：查询 x_0 之后，下一次查询取 x_- 还是 x_+ 由已出现的分支决定。覆盖中心必须提前为两个可能的下一步都指定值，不能在分支确定后临时增加一棵新的中心树。




图 5.6 深度为 2 的固定查询树。根查询 x_0 ，左右分支对应 $\epsilon_1 = -1$ 与 $+1$ ；各节点旁的 $v_1, v_2(\pm 1)$ 是一棵覆盖中心预先指定的值，表示近似值而非真实反馈。固定两点输入只观察其中一条路径。

在固定输入上，覆盖中心是一组函数值；在查询树上，它必须为每个可能访问的节点预先指定一个实数。下面的覆盖条件沿每条路径比较误差，中心集合仍在路径出现之前确定。

定义 5.16 序贯覆盖与序贯覆盖数 给定深度为 T 的查询树 $\mathbf{x}$ 、非空实值函数类 $\mathcal{F}$ 和 $\varepsilon > 0$ 。实数树 $v = (v_t)$ 的每层映射为 $v_t : \{-1, 1\}^{t-1} \rightarrow \mathbb{R}$ 。若这些树组成的有限集合 $\mathcal{C}$ 满足：对每个 $f \in \mathcal{F}$ 和每条路径 $\varepsilon \in \{-1, 1\}^T$ ，都存在 $v \in \mathcal{C}$ 使

$$\left(\frac{1}{T} \sum_{t=1}^T |f(\mathbf{x}_t(\varepsilon_{1:t-1})) - v_t(\varepsilon_{1:t-1})|^2 \right)^{1/2} \leq \varepsilon, \quad (5.14)$$

则称 $\mathcal{C}$ 为该查询树上的序贯 ε -覆盖。其最小大小记为 $N_2^{\text{seq}}(\varepsilon, \mathcal{F}, \mathbf{x})$ ；不存在有限覆盖时取 $+\infty$ 。对所有深度为 T 的查询树取上确界，得到该深度下函数类的序贯覆盖数。

覆盖集合必须在选择具体函数与路径之前固定，其中每个 v 都为整棵树的节点赋值，并且第 t 层的值只依赖此前分支 $\varepsilon_{1:t-1}$ 。针对不同的 f 与路径可以从该固定集合中选择不同 v ；不能做的是在看到完整未来后临时构造一个不属于预定覆盖集合的数值序列。这样，每个中心在第 t 步只使用此前已经出现的分支，保留了逐步获得信息的限制。

序贯覆盖数对所有深度 T 查询树取最坏情形。比较固定输入与查询树之前，必须统一覆盖中心的约定：上一小节要求中心属于 $\mathcal{F}$ ，这里的实数树却不必由某个 $f \in \mathcal{F}$ 产生。因此在同一半径下，不能直接断言序贯覆盖数更大。例如 $T = 1$ 、 $\mathcal{F} = \{f_-, f_+\}$ ，其中 $f_- \equiv -1$ 、 $f_+ \equiv 1$ ，取 $\varepsilon = 1$ 。内部中心的固定覆盖需要两个函数，外部中心 $v_1 = 0$ 却能同时覆盖二者。

若固定输入的中心也允许是任意实值取值向量，则各层查询不随分支变化的树与这种固定输入覆盖一致。查询树还允许输入依赖历史，所以对所有查询树取最坏情形，不小于对所有固定输入取最坏情形。若已有固定输入上的外部覆盖，却希望改用类内中心，可在每个被函数类占据的外部 ε 球中选一个类内代表；三角不等式给出内部 2ε 覆盖，数量不增加。这个两倍半径的换算不能省去。反向比较仍需额外规则性。上述换算只对固定输入的取值向量逐球选代表；一般中心树可能在不同路径上分别接近不同函数，不一定有同一个函数能在所有路径上接近它，因此不能把这个换算不加证明地推广到任意外部中心树。与胖打散维相似，还可以定义带间隔的序贯打散维；它衡量函数类能否沿树的每条分支持续作出可分辨选择。概率界、在线遗憾或自适应采样保证还需要后续章节的随机与算法条件，这里只建立输入可适应变化时应使用的结构对象。

深度为 2 的树已经能展示固定覆盖与序贯覆盖的差别。设根节点查询 x_0 ；沿标签 $\varepsilon_1 = -1$ 的分支查询 x_- ，沿标签 $\varepsilon_1 = 1$ 的分支查询 x_+ ，并假设函数在这三个点上的值都属于 $[-B, B]$ 。把三个节点值分别量化到宽度不超过 ε 的区间，并为每个被函数类占据的三维网格单元保留一棵代表函数树，就得到序贯 ε -覆盖：左路径比较 (x_0, x_-) 上的两个值，右路径比较

(x_0, x_+) 上的两个值, 每条路径的均方根误差都不超过 ε 。固定两点覆盖只需描述一条已经选定的路径; 树覆盖必须在分支发生前同时准备 x_- 与 x_+ 处的值。因此, 不能等路径进入某个分支后, 再用一个未属于预定覆盖集合的新近似器补上所选分支。若每个节点最多使用 $Q = 1 + \lceil 2B/\varepsilon \rceil$ 个量化区间, 这个构造至多保留 Q^3 棵中心树; 它是一个可检验的上界, 不是最小序贯覆盖数的公式。

回到 $f_\star(x) = |x - 1/2|$, Bernstein 多项式在一致范数下随次数增加逼近它; 含结点 $1/2$ 的线性样条与两个 ReLU 单元则能精确表示它。前者的每个基系数影响全域, 样条的结点值只影响相邻片段, ReLU 单元决定折点及一侧的斜率变化。这些是对同一个目标的表示结论, 不是整个函数类共享一个有限覆盖的结论。加入核截面后的比较将在核建立后回接; 概率误差和在线算法保证也不由本节的确定性计数自动产生。

5.3 函数空间上的算子

近似函数还要用于实际操作, 例如计算积分、读取某个位置的值, 或求得另一个函数。输入函数只有近似精度时, 这些操作会不会把误差放大? 本节将操作写成空间之间的映射, 再用两边的范数衡量误差怎样传到输出。映射 $A : \mathcal{V} \rightarrow \mathcal{W}$ 称为算子; 本节主要研究线性算子, 即 $A(af + bg) = aAf + bAg$ 。定义域、输出空间及各自范数都必须固定。若存在有限常数 C 使 $\|Af\|_{\mathcal{W}} \leq C\|f\|_{\mathcal{V}}$, 称 A 有界, 其算子范数为

$$\|A\|_{\text{op}} = \sup_{\|f\|_{\mathcal{V}} \leq 1} \|Af\|_{\mathcal{W}}.$$

因此 $\|Af - Ag\| \leq \|A\|_{\text{op}}\|f - g\|$; 这里 C 限制的是输出范数相对于输入范数的比例, 所以它能控制输入误差传到输出时被放大多少。它没有限制任意输入的输出都小于同一个数。线性算子有界必连续; 反过来, 若在零点连续, 可取 $\delta > 0$ 使 $\|u\| < \delta$ 时 $\|Au\| < 1$, 对非零 f 代入 $u = \delta f / (2\|f\|)$, 使得 $\|Af\| \leq 2\|f\|/\delta$ 。所以对线性算子, 有界与连续等价。

输出为实数时, 算子称为泛函; 输出仍是函数时, 则得到函数之间的变换。这是按输出对象划分。下面还要问: 能否在内积中把算子从一侧转到另一侧? 变换是否保留非负二次型? 能否用有限个方向逼近? 这些问题分别引出伴随、正性、紧性和谱展开。一个算子可以同时具有其中多项性质。

5.3.1 线性泛函与标量读取

5.3.1.1 有界泛函与 Riesz 表示

对函数取加权积分、读出一个系数或在一点求值，都会把整条函数变成一个数。要判断这些读取操作是否稳定，需检查输入函数的小范数误差能否控制输出误差。

定义 5.17 有界线性泛函 设 $\mathcal{V}$ 为实赋范空间。线性泛函是线性映射 $L : \mathcal{V} \rightarrow \mathbb{R}$ 。若存在有限常数 $C \geq 0$ ，使 $|L(f)| \leq C\|f\|_{\mathcal{V}}$ 对所有 $f \in \mathcal{V}$ 成立，则称 L 有界。

有界不是要求 L 在整个空间中的输出有统一上限，而是要求输出大小相对于输入范数有统一上限。线性性使 $|L(f) - L(g)| \leq C\|f - g\|$ ；在赋范空间上，线性泛函的有界性与连续性等价。Hilbert 空间的内积给出一类直接的有界泛函： $L_h(f) = \langle f, h \rangle_{\mathcal{H}}$ 。Riesz 表示定理说明每个有界线性泛函都能这样表示²。

例如在 $L^2(\mu)$ 中，对固定 $w \in L^2(\mu)$ ，加权积分 $L_w(f) = \int f w d\mu$ 有界，常数可取 $\|w\|_2$ ；在有正交归一方向 e_j 的空间中，系数读取 $f \mapsto \langle f, e_j \rangle$ 的范数为 1。点值 $f \mapsto f(x)$ 则只有在点值良定义且满足定义 5.9 的点值不等式时才有界。因此“读出一个数”说明输出类型，还没有保证该读取规则稳定。

² J. B. Conway, *A Course in Functional Analysis*, Springer, 1990, 2nd ed.

定理 5.18 Riesz 表示定理 设 $\mathcal{H}$ 为实 Hilbert 空间。对每个有界线性泛函 $L : \mathcal{H} \rightarrow \mathbb{R}$ ，存在唯一的 $h_L \in \mathcal{H}$ ，使

$$L(f) = \langle f, h_L \rangle_{\mathcal{H}}, \quad f \in \mathcal{H}. \quad (5.15)$$

并且 $\|L\| = \|h_L\|_{\mathcal{H}}$ ，其中 $\|L\| = \sup_{\|f\|_{\mathcal{H}} \leq 1} |L(f)|$ 。

证明. 若 $L = 0$ ，取 $h_L = 0$ 即可。以下设 $L \neq 0$ 。核空间 $M = \ker L = \{f : L(f) = 0\}$ 是线性子空间；由于 L 连续， M 也是闭集。选取 $u \in \mathcal{H}$ 使 $L(u) \neq 0$ 。由定理 5.10，可以把 u 唯一分解为

$$u = P_M u + v, \quad v \in M^\perp.$$

若 $v = 0$ ，则 $u \in M$ ，与 $L(u) \neq 0$ 矛盾，故 $v \neq 0$ 。又因 $P_M u \in M = \ker L$ ，

$$L(v) = L(u) - L(P_M u) = L(u) \neq 0,$$

所以下面的除法合法。

对任意 $f \in \mathcal{H}$, 向量

$$f - \frac{L(f)}{L(v)}v$$

的 L 值为零, 因而属于 M 。它与 $v \in M^\perp$ 正交, 所以

$$0 = \left\langle f - \frac{L(f)}{L(v)}v, v \right\rangle_{\mathcal{H}} = \langle f, v \rangle_{\mathcal{H}} - \frac{L(f)}{L(v)}\|v\|_{\mathcal{H}}^2.$$

整理得到

$$L(f) = \left\langle f, \frac{L(v)}{\|v\|_{\mathcal{H}}^2}v \right\rangle_{\mathcal{H}}.$$

因此可取 $h_L = L(v)v/\|v\|_{\mathcal{H}}^2$ 。

若 h_1, h_2 都表示 L , 则 $\langle f, h_1 - h_2 \rangle = 0$ 对每个 f 成立。取 $f = h_1 - h_2$ 使得 $h_1 = h_2$ 。Cauchy-Schwarz 不等式给出 $|L(f)| \leq \|f\| \|h_L\|$, 所以 $\|L\| \leq \|h_L\|$; 当 $h_L \neq 0$ 时取 $f = h_L/\|h_L\|$ 得到反向不等式。 $h_L = 0$ 的情形也直接成立。 ■

5.3.1.2 点值泛函与再生核

整体误差小未必使每个点的函数值接近, 前面的尖峰例子已经说明这一点。若观测和预测通过点值进行, 就需要点值读取相对于空间范数稳定。刚才已证明稳定的线性读取可以表示为内积。现在把读取规则取为 $f \mapsto f(x)$, 找出表示这个点值读取的空间元素; 由这些元素之间的内积, 就能构造核。后面再用核求解拟合问题。

固定定义 5.9 中的 RKHS $\mathcal{H}$, 对每个 x 记点值泛函为 $\delta_x(f) = f(x)$ 。它线性且有界, 所以 Riesz 表示定理给出唯一元素 $K_x \in \mathcal{H}$, 使

$$f(x) = \langle f, K_x \rangle_{\mathcal{H}}, \quad f \in \mathcal{H}. \quad (5.16)$$

定义

$$K(x, z) = K_z(x) = \langle K_z, K_x \rangle_{\mathcal{H}},$$

便得到空间的再生核 (reproducing kernel)。式 (5.16) 说明“再生”的含义: 函数在 x 处的值可以由函数与核截面 $K_x = K(\cdot, x)$ 的内积读出。

在 $L^2([0, 1])$ 中, 前面的尖峰已经否定稳定点值; 在 RKHS 中则有明确的最优读取常数, 因为

$$|f(x)| \leq \|f\|_{\mathcal{H}} \|K_x\|_{\mathcal{H}} = \|f\|_{\mathcal{H}} \sqrt{K(x, x)}. \quad (5.17)$$

当 $K(x, x) > 0$ 时, 取 $f = K_x/\|K_x\|$ 便达到单位范数球上的上界。当 $K(x, x) = 0$ 时, $K_x = 0$, 该点的所有函数值都为零。因而最优常数确实为 $\|\delta_x\| = \sqrt{K(x, x)}$, 而不只是某个足够大的上界。

输入之间的核值也不能随意指定：必须让任何有限线性组合的平方长度非负。

定义 5.19 实正定核 设 $\mathcal{X}$ 非空。对称函数 $K : \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}$ 若对每个 $n \geq 1$ 、任意 $x_1, \dots, x_n \in \mathcal{X}$ 和 $a_1, \dots, a_n \in \mathbb{R}$ 都满足 $\sum_{i,j=1}^n a_i a_j K(x_i, x_j) \geq 0$ ，则称其为正定核 (positive definite kernel)。本章采用核理论中允许半正定的命名惯例。

从再生性质得到的核满足这个条件，因为

$$\sum_{i,j=1}^n a_i a_j K(x_i, x_j) = \left\| \sum_{i=1}^n a_i K_{x_i} \right\|_{\mathcal{H}}^2 \geq 0. \quad (5.18)$$

这里有限 Gram 矩阵指 $\mathbf{K} \in \mathbb{R}^{n \times n}$ ，其元素为 $\mathbf{K}_{i,j} = K(x_i, x_j)$ 。上式就是 $\mathbf{a}^\top \mathbf{K} \mathbf{a} \geq 0$ 。沿用核理论的惯例，“正定”允许有限 Gram 矩阵奇异；若非零系数和互异输入总使二次型严格为正，才称严格正定。

正定核的一个可直接核验的来源是有限维特征内积。给定映射 $\phi : \mathcal{X} \rightarrow \mathbb{R}^d$ ，令

$$K_\phi(x, z) = \langle \phi(x), \phi(z) \rangle_2.$$

对任意有限输入与实系数，

$$\sum_{i,j=1}^n a_i a_j K_\phi(x_i, x_j) = \left\| \sum_{i=1}^n a_i \phi(x_i) \right\|_2^2 \geq 0,$$

所以 K_ϕ 满足有限半正定条件。例如，当 $\mathcal{X} \subseteq \mathbb{R}$ 且 $\phi(x) = (1, x)^\top$ 时，得到 $K_\phi(x, z) = 1 + xz$ 。

示例 5.20 二维函数空间中的再生核 令 $\mathcal{X} = [-1, 1]$ ， $\mathcal{H} = \{f(x) = a + bx : a, b \in \mathbb{R}\}$ ，内积为 $\langle a + bx, c + dx \rangle = ac + bd$ 。输入 z 的核截面是 $K_z(x) = 1 + zx$ ，因为 $\langle a + bx, 1 + zx \rangle = a + bz = f(z)$ 。于是 $K(x, z) = 1 + xz$ ， $\|f\|_{\mathcal{H}}^2 = a^2 + b^2$ ，点值上界为 $|f(z)| \leq \sqrt{1 + z^2} \sqrt{a^2 + b^2}$ 。

这个有限维例子说明，再生核空间不一定是无限维的。取三个互异输入时，Gram 矩阵秩仍至多为 2，因为只有两个独立特征方向；核半正定不保证每个有限 Gram 矩阵都可逆。表示同一函数的三项核系数可能不唯一，而空间中的函数仍可由严格凸的正则化目标唯一决定。

图 5.7 把 $f \mapsto f(3/4)$ 画成系数平面上的读取。系数平面上的圆限制 $a^2 + b^2$ ，每条平行直线则对应相同的 $f(3/4)$ 。单位范数球中的最大点值发生在核方向上，所以点值上界中的 $\sqrt{1 + z^2}$ 正是该方向的长度。




图 5.7 仿射 RKHS 中读取 $f(3/4) = a + 3b/4$ 。灰圆表示 $a^2 + b^2 \leq 1$ ，黄箭头是核截面 $K_{3/4}$ 对应的系数 $(1, 3/4)$ ；灰平行线为相同点值。黄圆点 $(4/5, 3/5)$ 达到单位范数球上的最大点值 $5/4$ 。这里坐标是函数系数，不是输入位置。图为解析教学示例。

核已建立，可以把它接回前面的表示比较。仍固定目标

$$f_{\star}(x) = \left| x - \frac{1}{2} \right|, \quad x \in [0, 1],$$

可以看清表示选择的差异。全局多项式用一组遍及整个区间的基函数逼近折点；分段线性样条只需把 $1/2$ 设为结点，就能精确表示 $f_{\star}$ 。使用宽度 $\sigma > 0$ 的高斯核

$$K_{\sigma}(x, z) = \exp\left(-\frac{(x - z)^2}{2\sigma^2}\right)$$

时，可以由若干主要作用于中心附近的核截面 $K_{\sigma}(\cdot, x_i)$ 组合出平滑逼近。高斯核离开中心后衰减，却没有紧支撑；“局部”不表示中心以外恰好为零。有限组合仍是光滑函数，不能在有限核宽度下精确产生折点。带 ReLU 激活的单隐藏层网络则可直接写成

$$f_{\star}(x) = \text{ReLU}\left(x - \frac{1}{2}\right) + \text{ReLU}\left(\frac{1}{2} - x\right).$$

这些差别来自表示能否保留目标的尖点、以及单个系数会影响多大范围，不能只由“哪一类更通用”判断。高斯函数确实是正定核，因为

$$K_{\sigma}(x, z) = e^{-x^2/(2\sigma^2)} e^{-z^2/(2\sigma^2)} \sum_{k=0}^{\infty} \frac{x^k z^k}{\sigma^{2k} k!};$$

每个有限部分和都是特征内积核，有限 Gram 二次型取极限仍非负。固定宽度的核截面族可以一致逼近 $[0, 1]$ 上的连续函数，这还需超出正定性的理由：对中心 z 作 k 阶导数并取 $z = 0$ ，得到 $e^{-x^2/(2\sigma^2)}$ 乘一个 k 次多项式，最高次系数非零。这些导数可由 $z = 0, h, \dots, kh$ 处的有限差分一致逼近，故核截面张成的闭包包含 $e^{-x^2/(2\sigma^2)}p(x)$ 的所有多项式 p 。对连续函数 $f(x)e^{x^2/(2\sigma^2)}$ 使用 Bernstein 逼近，便得到所需稠密性。这里中心数可以增长；有限个固定中心本身不构成稠密族。相比之下，正定核 $1 + xz$ 始终只产生仿射函数，不能任意精度逼近折点目标。

表示	对 $f_*(x) = x - 1/2 $ 的有限表示	调整的范围
全局多项式	可逼近，有限次数不能精确产生折点	一个系数通常影响整个区间
分段线性样条	将 $1/2$ 设为结点即可精确表示	结点邻域内的分段变化
固定正宽度的高斯核有限和	保持光滑，可逼近但不能精确产生折点	核中心附近的变化，宽度决定影响范围
两个 ReLU 单元	上式直接给出精确表示	隐藏单元的位置和方向决定折点

表 5.1 同一个连续目标的不同表示。有限表示的结构与整个表示族的稠密性是不同问题。

5.3.1.3 正定核与空间构造

上面先规定函数空间，再用稳定点值构造核。实践中也可以先给定输入之间的核值，但必须问：这些核值能否来自某个函数空间？下面的构造证明，有限半正定条件已经足够，不需要输入域带有拓扑或测度³。

³ N. Aronszajn, *Theory of Reproducing Kernels* In Transactions of the American Mathematical Society, 1950, vol. 68, no. 3, pp. 337–404

定理 5.21 正定核的 RKHS 构造 设 $\mathcal{X}$ 为任意非空集合, $K : \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}$ 对称, 并满足式(5.18)的有限半正定条件。则存在唯一的函数 RKHS $\mathcal{H}_K$ 以 K 为再生核；这里的唯一性指保持每个函数不变的等距同构。

证明. 先令 $\mathcal{V}_0$ 为核截面符号 K_x 的形式有限线性组合所成的向量空间：

$$\mathcal{V}_0 = \left\{ \sum_{i=1}^n a_i K_{x_i} : n \in \mathbb{N}, a_i \in \mathbb{R}, x_i \in \mathcal{X} \right\}.$$

这里先把 K_x 作为由 x 索引的符号。一组系数和这些符号组成一个形式和，暂时不因两个形式和具有相同的函数值就把它合并。下面将证明应当合并哪些表示。对 $f = \sum_i a_i K_{x_i}$ 和 $g = \sum_j b_j K_{z_j}$ 定义

$$\langle f, g \rangle_0 = \sum_{i,j} a_i b_j K(x_i, z_j). \quad (5.19)$$

正定性只保证 $\langle f, f \rangle_0 \geq 0$ ，还可能有非零形式和的长度为零。令

$$\mathcal{N} = \{f \in \mathcal{V}_0 : \langle f, f \rangle_0 = 0\}.$$

半内积仍满足 Cauchy-Schwarz 不等式: 对 $\langle g, g \rangle_0 > 0$, 最小化非负二次式 $\langle f - tg, f - tg \rangle_0$ 即可得到原来的证明; 若 $\langle g, g \rangle_0 = 0$, 非负式 $\langle f + tg, f + tg \rangle_0 = \langle f, f \rangle_0 + 2t\langle f, g \rangle_0$ 对所有实数 t 成立, 迫使交叉项为零。因此 $f \in \mathcal{N}$ 时 $\langle f, g \rangle_0 = 0$ 对所有 g 成立。这又说明 $\mathcal{N}$ 是线性子空间, 且改变代表元只增加与所有元素正交的项。因此可以把相差一个 $\mathcal{N}$ 中元素的形式和视为同一对象, 即取商空间。这样, 式 (5.19) 成为真正的内积。

还需证明这些等价类可以解释为函数, 且不同等价类不会给出同一个函数。对形式和 $f = \sum_i a_i K_{x_i}$, 定义

$$(Jf)(x) = \sum_i a_i K(x, x_i) = \langle f, K_x \rangle_0.$$

若 $f \in \mathcal{N}$, 则

$$|(Jf)(x)|^2 = |\langle f, K_x \rangle_0|^2 \leq \langle f, f \rangle_0 K(x, x) = 0,$$

所以 Jf 处处为零。反过来, 若 Jf 处处为零, 则

$$\langle f, f \rangle_0 = \sum_i a_i (Jf)(x_i) = 0,$$

故 $f \in \mathcal{N}$ 。因此 $\ker J = \mathcal{N}$, 商空间 $\mathcal{H}_0 = \mathcal{V}_0 / \mathcal{N}$ 可单射地识别为函数空间, 并且其中的函数满足

$$f(x) = \langle f, K_x \rangle_0.$$

对这个内积空间作完备化, 得到 Hilbert 空间 $\mathcal{H}_K$ 。还要确认完备化后的抽象极限仍是函数。若 $(f_m) \subset \mathcal{H}_0$ 在核范数下为柯西序列, 则对每个 x ,

$$|f_m(x) - f_\ell(x)| \leq \|f_m - f_\ell\|_0 \sqrt{K(x, x)},$$

所以 $(f_m(x))$ 是实数柯西序列。定义 $f(x) = \lim_m f_m(x)$ 。若另一个柯西序列与 (f_m) 表示同一个完备化元素, 同一不等式保证两者逐点极限相同。故完备化元素具有良定义的函数值, 且内积连续性给出

$$f(x) = \lim_m \langle f_m, K_x \rangle_0 = \langle f, K_x \rangle_{\mathcal{H}_K}.$$

再生性质因此延伸到整个 $\mathcal{H}_K$ 。这个逐点解释在完备化后仍是单射: 若 $f \in \mathcal{H}_K$ 处处取零, 则 f 与每个 K_x 正交; 核截面的线性张成 $\mathcal{H}_0$ 在其完备化 $\mathcal{H}_K$ 中稠密, 所以 f 与整个空间正交, 只能有 $f = 0$ 。

唯一性也由这个构造确定。若另一个 RKHS $\widetilde{\mathcal{H}}$ 也以 K 为核, 则有限核截面和在两个空间中的内积都由式 (5.19) 决定。核截面的线性张成在任一空间中都稠密; 否则与所有 K_x 正交的函数 f 满足 $f(x) = 0$ 对所有 x 成立,

只能是零函数。所以有限核截面和之间的恒等映射唯一地延伸为两个完备空间之间的等距同构。 ■

定理5.21说明，验证所有有限 Gram 矩阵半正定就足以定义一个 RKHS。它不同于 Mercer 谱展开。后者通常还假设 $\mathcal{X}$ 是紧空间、 K 连续，并选定具有适当支持的有限测度；这些条件使积分算子

$$(T_K f)(x) = \int_{\mathcal{X}} K(x, z) f(z) d\mu(z)$$

成为紧自伴算子，从而可以用特征值与特征函数展开 K 。一般正定核即使不满足这些拓扑和测度条件，仍有上述 RKHS 构造。因而，核的合法性、核的谱展开以及谱展开的一致收敛是三项条件不同的结论。

5.3.2 函数间的线性算子

输出仍是函数时，操作公式必须连同两个空间一起理解。例如弱求导 $D : H^1(a, b) \rightarrow L^2(a, b)$ 满足 $\|Df\|_2 \leq \|f\|_{H^1}$ ，因而是有界算子；同一公式若给定义域 $C^1([0, 1])$ 只配一致范数，却不是到 $C([0, 1])$ 一致范数的有界算子： $f_n(x) = \sin(nx)/n$ 趋于零，而 $\|f'_n\|_\infty = 1$ 。在全部 L^2 上，求导甚至未必有 L^2 值。同一个求导公式，在一种范数下能控制误差，在另一种范数下却可能把趋零误差变成不趋零的输出。判断它能否使用，必须同时给出输入空间、输出空间和两边的范数。

5.3.2.1 有界算子与伴随关系

要比较算子输出与某个测试方向的内积，需要把这个测试方向变换到输入空间。

定义 5.22 Hilbert 空间之间的伴随算子 设 $\mathcal{H}, \mathcal{G}$ 为实 Hilbert 空间， $S : \mathcal{H} \rightarrow \mathcal{G}$ 为有界线性算子，即存在有限 $C \geq 0$ 使 $\|Sf\|_{\mathcal{G}} \leq C\|f\|_{\mathcal{H}}$ 。其伴随是满足

$$\langle Sf, g \rangle_{\mathcal{G}} = \langle f, S^*g \rangle_{\mathcal{H}} \quad (f \in \mathcal{H}, g \in \mathcal{G})$$

的有界线性算子 $S^* : \mathcal{G} \rightarrow \mathcal{H}$ 。

对固定 g ，左边是关于 f 的有界线性泛函，Riesz 表示给出唯一的 S^*g ；表示元的唯一性又保证 S^* 线性，且 $\|S^*g\|_{\mathcal{H}} \leq C\|g\|_{\mathcal{G}}$ 。因此伴随确实存在且唯一。它把内积中的算子换到另一侧，并不要求 S 可逆；有限维实正交坐标中它对应通常的转置；复内积空间使用相应的复数版本，才对应共轭转置。后面的 Mercer 证明会对空间之间的包含映射使用同一概念。

一个可复算的例子是 $A : L^2(0,1) \rightarrow L^2(0,1)$, $(Af)(x) = \int_0^x f(t) dt$ 。Cauchy-Schwarz 给出 $|Af(x)|^2 \leq x\|f\|_2^2$, 所以 $\|A\|_{\text{op}} \leq 1/\sqrt{2}$ 。交换三角区域中的积分可得

$$\langle Af, g \rangle = \int_0^1 f(t) \left(\int_t^1 g(x) dx \right) dt, \quad (A^*g)(t) = \int_t^1 g(x) dx.$$

例如 $A1(x) = x$, 而 $A^*1(t) = 1 - t$ 。伴随把输出测试的累积权重送回输入, 并不把 Af 反解成 f , 也不一定等于 A 自身。

伴随已经说明怎样把算子换到内积另一侧。接下来要检查三个有助于分解算子的性质: 换到另一侧后算子是否相同, 输入与输出的内积是否总非负, 以及有界输入序列的输出能否取到收敛子列。它们分别对应自伴、正和紧。

定义 5.23 自伴、正与紧算子 设 $T : \mathcal{H} \rightarrow \mathcal{H}$ 为实 Hilbert 空间上的有界线性算子。若对所有 $f, g \in \mathcal{H}$ 有 $\langle Tf, g \rangle = \langle f, Tg \rangle$, 称 T 自伴, 即 $T^* = T$ 。若 T 自伴且 $\langle Tf, f \rangle \geq 0$ 对每个 $f \in \mathcal{H}$ 成立, 称 T 为正算子。若对每个有界序列 (f_n) , 序列 (Tf_n) 都具有在 $\mathcal{H}$ 中范数收敛的子列, 称 T 为紧算子。

紧性也可用于 $S : \mathcal{H} \rightarrow \mathcal{G}$, 此时要求有界输入序列的像在 $\mathcal{G}$ 中有范数收敛子列, 不要求两个空间相同。自伴与正性则必须在同一 Hilbert 空间上比较 T 与 T^* 或 $\langle Tf, f \rangle$ 。有界性只控制输出大小, 紧性还要求每个有界输入序列的输出都有收敛子列。在无限维 ℓ^2 中, 恒等算子有界、自伴且为正, 却不紧: 前文的单位向量序列经过它仍然两两相距 $\sqrt{2}$, 没有收敛子列。后面的有限秩逼近正是建立紧性的途径。

5.3.2.2 积分算子与核谱展开

有限 Gram 矩阵只比较已选输入之间的核值。要研究核在整个输入范围内怎样作用于函数, 需要先指定积分测度, 再建立积分算子。给定测度空间 $(\mathcal{X}, \mu)$, 假设 μ 为 σ 有限测度, 即 $\mathcal{X}$ 可由可数个有限测度可测集覆盖。对可测平方可积核 $K \in L^2(\mu \otimes \mu)$, 定义

$$(T_K f)(x) = \int_{\mathcal{X}} K(x, z) f(z) d\mu(z). \quad (5.20)$$

Fubini 定理保证几乎所有 x 的核截面属于 $L^2(\mu)$, 故积分几乎处处存在。Cauchy-Schwarz 进一步给出

$$|T_K f(x)|^2 \leq \left(\int |K(x, z)|^2 d\mu(z) \right) \|f\|_2^2, \quad \|T_K f\|_2 \leq \|K\|_{L^2(\mu \otimes \mu)} \|f\|_2.$$

所以输出确实属于 L^2 ，且 $\|T_K\|_{\text{op}} \leq \|K\|_{L^2(\mu \otimes \mu)}$ 。核在零测集上的修改不影响该算子。

T_K 还是紧算子。把 K 在 $L^2(\mu \otimes \mu)$ 中用有限个矩形指示函数的线性组合逼近，相应积分算子只有有限维值域。例如 $K_N(x, z) = \sum_{j=1}^N a_j \mathbb{1}_{A_j}(x) \mathbb{1}_{B_j}(z)$ ，其中集合测度有限，则 $T_{K_N} f$ 落在 $\{\mathbb{1}_{A_j}\}$ 的张成空间。这类简单核的稠密性来自 σ 有限乘积测度的简单函数逼近。上面的估计使 $\|T_K - T_{K_N}\|_{\text{op}} \rightarrow 0$ 。有限秩算子把有界序列送入有限维有界集；逐个抽取子列并作对角选择，再用一致算子范数误差，就得到 $T_K f_n$ 的柯西子列。输出空间完备，故该子列收敛，这说明有限秩算子的范数极限确实紧。

对称性 $K(x, z) = K(z, x)$ 几乎处处成立时，交换积分给出 $T_K^* = T_K$ ；绝对可积性由 $K \in L^2(\mu \otimes \mu)$ 和 $(x, z) \mapsto f(z)g(x) \in L^2$ 保证。正性还要另查。若 K 有处处有限、可测的正定核代表，则 T_K 为正：先把 f 限制在有限测度集 E 上，并令 $|f|$ 及 $K(x, x)$ 在 E 上有界。将有限半正定不等式 $\sum_{i,j=1}^n f(x_i)f(x_j)K(x_i, x_j) \geq 0$ 在 E^n 上积分，对 $\mu(E) > 0$ 除以 $n\mu(E)^{n-2}$ ，得到

$$(n-1) \int_{E \times E} f(x)K(x, z)f(z) d\mu(x)d\mu(z) + \mu(E) \int_E f(x)^2 K(x, x) d\mu(x) \geq 0.$$

除以 $n-1$ 并令 $n \rightarrow \infty$ ，双积分非负。由 σ 有限性可选递增的这类截断集覆盖 X ； $f \mathbb{1}_E \rightarrow f$ 于 L^2 ，有界性将结论传给任意 f 。这里没有把算子正性与核处处正定性混同：算子忽略零测集，任意修改零测集上的核值可能破坏某个有限 Gram 矩阵，却不改变算子。

这里用“特征方向”表示非零向量 h 满足 $Th = \lambda h$ ；对应的特征值 λ 说明沿这个方向被缩放多少。零特征值方向属于 $\ker T$ ，被算子送到零；以后用特征值倒数计算时，必须把这些方向排除。紧自伴谱定理说明， T_K 的非零谱由有限重数的实特征值组成；若非零特征值无限多，它们只能聚集到 0。相应特征向量与零空间的闭线性张成等于整个 Hilbert 空间；换言之，一般元素由这些方向的正交级数在 Hilbert 范数下收敛得到。这个结论给出 $L^2(\mu)$ 中的算子谱，却还没有保证核本身在每个 (x, z) 处都等于特征函数级数⁴。

Mercer 定理补上点态展开所需的条件。有限 Gram 矩阵 $[K(x_i, x_j)]_{i,j}$ 只记录有限个输入之间的关系；积分算子的谱则依赖整个输入空间及其测度。要把后者变成处处成立的连续函数展开，还必须保证测度没有忽略一个非空开区域。为了用级数逐项记录展开，还需保证所涉及的非零方向可以按可数指标列出。“可分空间”指存在可数稠密子集；下面将由紧度量输入域证明相应 RKHS 可分。一般无限维空间不自动满足这一点。

⁴ J. B. Conway, *A Course in Functional Analysis*, Springer, 1990, 2nd ed.

示例 5.24 同一个核在两种内积下的坐标 沿用例 5.20 的仿射核 $K(x, z) = 1 + xz$, 在 $[-1, 1]$ 上增加测度 $d\mu(x) = dx/2$ 。核已经固定了 RKHS 内积; 测度另行决定 $L^2(\mu)$ 内积。因为 $\int x d\mu(x) = 0$ 、 $\int x^2 d\mu(x) = 1/3$, 同一个函数 $f(x) = a + bx$ 的两种长度为

$$\begin{aligned} \|f\|_{\mathcal{H}_K}^2 &= a^2 + b^2, \\ \|f\|_{L^2(\mu)}^2 &= \int_{-1}^1 (a + bx)^2 \frac{dx}{2} = a^2 + \frac{b^2}{3}. \end{aligned} \quad (5.21)$$

因此 $h_1(x) = 1$ 、 $h_2(x) = x$ 是 RKHS 中的标准正交基, 而在 $L^2(\mu)$ 中, 同样两个方向要写成 $\psi_1(x) = 1$ 、 $\psi_2(x) = \sqrt{3}x$ 才能归一化。

积分算子的作用也可直接计算。对任意 $g \in L^2(\mu)$,

$$(T_K g)(x) = \int g(z) d\mu(z) + x \int zg(z) d\mu(z).$$

代入 ψ_1, ψ_2 , 得到 $T_K \psi_1 = \psi_1$ 、 $T_K \psi_2 = \psi_2/3$, 所以正特征值为 $\mu_1 = 1$ 、 $\mu_2 = 1/3$ 。其余与 $1, x$ 都正交的函数被送到零, 属于算子的零空间。核展开于是为

$$K(x, z) = 1 + \frac{1}{3}(\sqrt{3}x)(\sqrt{3}z) = 1 + xz.$$

这里 ψ_1, ψ_2 只张成 $L^2(\mu)$ 中的仿射函数子空间, 不是整个 $L^2(\mu)$ 的基。包含映射 $S: \mathcal{H}_K \rightarrow L^2(\mu)$ 保持函数值, 即 $Sf = f$, 却不保持范数: $Sh_1 = \psi_1$ 、 $Sh_2 = \psi_2/\sqrt{3}$ 。在两边各自的归一化坐标中, 它将第二个方向的长度缩为 $1/\sqrt{3}$ 。

比较对象	RKHS $\mathcal{H}_K$	$L^2(\mu)$
$f(x) = a + bx$ 的范数平方	$a^2 + b^2$	$a^2 + b^2/3$
常数方向, $\mu_1 = 1$	$h_1(x) = 1$	$\psi_1(x) = 1$
线性方向, $\mu_2 = 1/3$	$h_2(x) = x$	$\psi_2(x) = \sqrt{3}x$

表 5.2 仿射核在 RKHS 与 $L^2(dx/2)$ 中的尺度对照。两列分别按各自内积归一化; 表中只列出积分算子的两个正特征方向。

这个例子把核、积分测度和特征函数联系起来。一般的连续正定核也能这样展开, 但需要把有限个方向的分解推广为级数, 并保证核值在整个输入域上得到一致控制。

定理 5.25 连续正定核的 Mercer 展开 设 $\mathcal{X}$ 为非空紧度量空间, μ 为有限、全支撑 Borel 测度, 即每个非空开集都有正测度。设 $K : \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}$ 连续、对称, 且对任意有限输入组满足正定核的半正定条件。则 T_K 是 $L^2(\mu)$ 上的紧、自伴、正算子。其正特征值按重数记为 (μ_j) , 可为有限个或可数无穷个; 相应特征函数可选为连续的 $L^2(\mu)$ 标准正交函数 (ψ_j) , 并有

$$K(x, z) = \sum_{j: \mu_j > 0} \mu_j \psi_j(x) \psi_j(z). \quad (5.22)$$

级数在 $\mathcal{X} \times \mathcal{X}$ 上绝对且一致收敛, 且 $\sum_j \mu_j = \int K(x, x) d\mu(x) < \infty$ 。若 $K \equiv 0$, 右侧为空和。 T_K 可能另有零空间, 零特征值不进入这个展开。

证明. 证明的关键是先在 RKHS 中分解, 再用连续性把逐点结论加强为一致结论。由前面的 Moore–Aronszajn 构造得到 $\mathcal{H}_K$ 。核连续意味着

$$\|K_x - K_z\|_{\mathcal{H}_K}^2 = K(x, x) + K(z, z) - 2K(x, z) \longrightarrow 0 \quad (z \rightarrow x),$$

所以每个 $f \in \mathcal{H}_K$ 连续。紧度量空间有可数稠密子集, 其核截面的张成在 $\mathcal{H}_K$ 中稠密: 任意 K_x 都可用稠密子集的核截面依上面的范数连续性逼近, 而全部核截面的张成已知稠密。再把有限组合的系数取为有理数, 就得到可数稠密集, 故该空间可分; 这使下面的标准正交基和级数可以按可数指标列出。

令 $S : \mathcal{H}_K \rightarrow L^2(\mu)$ 为包含映射 $Sf = f$ 。点值上界保证 $\|Sf\|_{L^2}^2 \leq \|f\|_{\mathcal{H}_K}^2 \int K(x, x) d\mu(x)$ 。若 $Sf = 0$, 连续函数 f 几乎处处为零; 全支撑性排除了非零连续函数只在一个零测开区域出现的可能, 故 $f = 0$, 即 S 单射。取 $\mathcal{H}_K$ 的标准正交基 (e_j) , 再生性质和 Parseval 等式给出

$$\begin{aligned} \sum_j \|Se_j\|_{L^2}^2 &= \int \sum_j |e_j(x)|^2 d\mu(x) \\ &= \int \|K_x\|_{\mathcal{H}_K}^2 d\mu(x) = \int K(x, x) d\mu(x) < \infty. \end{aligned}$$

非负积分与求和的交换由单调收敛保证。这一有限尾和可以直接控制有限秩逼近: 将输入投影到前 N 个基方向所得的有限秩算子逼近 S , 算子范数误差平方不超过上述级数的尾和, 所以 S 紧。

用 Riesz 表示定义伴随 S^* 。对 $g \in L^2(\mu)$, 再生性质给出

$$(S^*g)(x) = \langle S^*g, K_x \rangle_{\mathcal{H}_K} = \langle g, SK_x \rangle_{L^2} = \int g(z) K(z, x) d\mu(z),$$

因而 $SS^* = T_K$ 。这也直接核对了 T_K 的正性。在例 5.24 中, S 的归一化坐标矩阵为 $\text{diag}(1, 1/\sqrt{3})$, 伴随在这两个方向上具有同样的反向坐标矩阵; S^*S 与 SS^* 便分别在两个空间中具有特征值 $1, 1/3$ 。一般情形也通过这两个组合算子联系两边的特征方向。紧正算子 S^*S 没有零特征方向, 故其标准正交特征向量 (h_j) 构成 $\mathcal{H}_K$ 的基。设相应正特征值为 μ_j , 令 $\psi_j = Sh_j/\sqrt{\mu_j}$ 。于是 ψ_j 连续且在 $L^2(\mu)$ 中标准正交, $T_K\psi_j = \mu_j\psi_j$ 。反向地, T_K 的任意正特征方向通过 S^* 对应到 S^*S 的同特征值方向, 所以没有遗漏正特征值。对 K_x, K_z 在 (h_j) 中应用 Parseval 等式, 得到

$$K(x, z) = \sum_j h_j(x)h_j(z) = \sum_j \mu_j \psi_j(x)\psi_j(z).$$

特别地, 对角展开的余项 $r_N(x) = K(x, x) - \sum_{j \leq N} \mu_j \psi_j(x)^2$ 连续、非负, 并逐点单调降到零。给定 $\varepsilon > 0$, 开集 $\{x : r_N(x) < \varepsilon\}$ 随 N 增加, 且覆盖紧空间; 有限覆盖保证某一个 N 已覆盖全部空间, 因此 r_N 一致趋于零。Cauchy-Schwarz 不等式进一步给出

$$\sum_{j > N} |\mu_j \psi_j(x)\psi_j(z)| \leq \sqrt{r_N(x)r_N(z)} \longrightarrow 0 \quad \text{一致于}(x, z).$$

这同时证明绝对收敛及一致收敛。对对角展开积分并用标准正交性, 可得 $\int K(x, x) d\mu(x) = \sum_j \mu_j$ 。零核的情形直接成立。■

上述证明说明, 全支撑性保证连续函数若几乎处处为零, 就处处为零: 它不能在某个未被测度看见的开区间中仍然非零。紧致性将连续的递减余项从逐点控制提升为统一控制。紧自伴算子谱、Mercer 点态展开与有限 Gram 矩阵分解因此是三个层次的结论, 不能仅从有限矩阵的半正定性推断全域的一致展开⁵。

在上述 Mercer 条件下, $\mu_j > 0$ 的方向构成相应 RKHS 的谱坐标。函数可写成 $f = \sum_j b_j \psi_j$, 其范数为

$$\|f\|_{\mathcal{H}_K}^2 = \sum_{j: \mu_j > 0} \frac{b_j^2}{\mu_j}. \quad (5.23)$$

这个式子不仅是形式记号。证明中 $h_j = \sqrt{\mu_j} \psi_j$ 是 $\mathcal{H}_K$ 的正交归一基; 写 $f = \sum_j a_j h_j$, 便有 $b_j = a_j \sqrt{\mu_j}$, Parseval 等式给出上述范数。反过来, 只要 $\sum_j b_j^2 / \mu_j < \infty$, 相应级数就在 $\mathcal{H}_K$ 中收敛, 从而给出合法函数, 并逐点收敛到该函数; 由于紧域上核对角有界, 这里还一致收敛。仅有 $\sum_j b_j^2 < \infty$ 只保证 L^2 成员资格, 不足以保证属于 RKHS。 L^2 零特征方向不在此展开中, 不能对零特征值取倒数。在相同 L^2 系数下, 小正特征值的方向要付出更大的核范数代价。这种代价怎样改变拟合结果, 接下来在优化中计算。

⁵ J. Mercer, *Functions of Positive and Negative Type, and Their Connection with the Theory of Integral Equations* In *Philosophical Transactions of the Royal Society of London, Series A*, 1909, vol. 209, pp. 415–446

回到例 5.24, $f(x) = a + bx$ 在 $L^2(\mu)$ 归一化方向中的系数为 $b_1 = a$ 、 $b_2 = b/\sqrt{3}$ 。式 (5.23) 将第二个系数的平方除以 $\mu_2 = 1/3$, 恢复 $a^2 + b^2$, 与表 5.2 中的核范数一致。小特征值在这里补偿的是两种归一化的尺度差异。更换积分测度会改变特征值和特征函数, 但不会改变已固定的核范数。

5.4 函数空间上的优化

前面已经能够比较、投影和读取函数, 现在令函数本身成为未知量。目标泛函 J 给每个候选函数一个评价, 问题写成 $\inf_{f \in C} J(f)$ 。 $C = \mathcal{H}$ 表示没有额外可行约束, 即使 J 中含有范数惩罚; 只有明确要求 f 属于某个较小集合 C 时, 才增加可行约束。以下以 Hilbert 空间及 RKHS 为主, 不把结论直接推广到一般 Banach 空间。拟合误差可以只比较有限个观测读数, 也可以比较整个输入范围上的积分误差。两种目标利用的信息不同; 先建立函数的一阶变化与最优判据, 再分别求解。

5.4.1 函数微分与最优性条件

5.4.1.1 函数微分与梯度

向量优化中的小位移在这里变为小函数扰动 h , 例如用 $f + h$ 代替 f 。设 J 在 f 的 Hilbert 空间开邻域内取有限实值。沿方向 h 的方向导数定义为

$$J'(f; h) = \lim_{t \rightarrow 0} \frac{J(f + th) - J(f)}{t},$$

前提是这个双侧极限存在。它只检查一条直线上的变化; 要对所有足够小的扰动使用同一个线性近似, 还需要更强的条件。

定义 5.26 函数泛函的 Fréchet 微分与梯度 设 $\mathcal{H}$ 为实 Hilbert 空间, J 在 f 的开邻域内取有限实值。若存在有界线性泛函 $DJ(f) : \mathcal{H} \rightarrow \mathbb{R}$, 使

$$J(f + h) = J(f) + DJ(f)[h] + r_f(h), \quad \frac{|r_f(h)|}{\|h\|_{\mathcal{H}}} \rightarrow 0 \quad (\|h\|_{\mathcal{H}} \rightarrow 0),$$

则称 J 在 f 处 Fréchet 可微, $DJ(f)$ 为其微分, 也称 Fréchet 导数 (Fréchet derivative)。由 Riesz 表示, 存在唯一 $\nabla_{\mathcal{H}} J(f) \in \mathcal{H}$ 满足

$$DJ(f)[h] = \langle \nabla_{\mathcal{H}} J(f), h \rangle_{\mathcal{H}}.$$

这个空间元素称为相对于该内积的梯度。

微分把一个扰动函数变成一阶目标变化, 是有界线性读取; 梯度则用空间里的一个方向表示这项读取。Fréchet 可微蕴含各方向导数存在且等于

$DJ(f)[h]$, 反过来未必成立。例如在二维系数平面上令 $J(a, b) = a^3/(a^2+b^2)$ (非零点), 并令 $J(0, 0) = 0$ 。原点沿 $(u, v) \neq 0$ 的双侧方向导数为 $u^3/(u^2+v^2)$, 它并非方向的线性函数: 在 $(1, 0)$ 与 $(0, 1)$ 上的值之和为 1, 在 $(1, 1)$ 上的值却为 $1/2$, 故不能作为 Fréchet 微分。

即使所有方向导数恰好组成有界线性泛函, 仍可能缺少对方向的统一余项控制。在同一个二维函数系数空间中定义

$$Q(a, b) = \begin{cases} \frac{a^3 b}{a^4 + b^2}, & (a, b) \neq (0, 0), \\ 0, & (a, b) = (0, 0). \end{cases}$$

由 $2|a^2 b| \leq a^4 + b^2$ 得 $|Q(a, b)| \leq |a|/2$, 所以 Q 在原点连续。对固定方向 (u, v) , 若 $v = 0$, 则 $Q(tu, tv) = 0$; 若 $v \neq 0$, 则 $Q(tu, tv)/t = tu^3 v/(t^2 u^4 + v^2) \rightarrow 0$ 。因此所有方向导数都为零, 候选微分只能是零泛函。但沿曲线 $b = a^2$, 有 $Q(a, a^2) = a/2$, 且 $|Q(a, a^2)|/\sqrt{a^2 + a^4} \rightarrow 1/2$, 余项不满足 Fréchet 条件。逐条直线上的极限不能代替对全部小扰动的统一线性近似。

对平方距离目标 $J(f) = \frac{1}{2}\|f - y\|_{\mathcal{H}}^2$, 直接展开得到

$$J(f + h) - J(f) = \langle f - y, h \rangle_{\mathcal{H}} + \frac{1}{2}\|h\|_{\mathcal{H}}^2.$$

余项除以 $\|h\|$ 趋于零, 所以 $DJ(f)[h] = \langle f - y, h \rangle$, 梯度为 $f - y$ 。这里求的是目标对未知函数 f 的微分, 不是 $f(x)$ 对输入 x 的导数; 即使 y 有尖点, 这个平方距离泛函仍然可微。

梯度还依赖内积的选择, 而不只是目标的表达式。例如在仿射函数 $f(x) = a + bx$ 上, 目标 $J(f) = (a^2 + b^2)/2$ 的微分始终是 $DJ(f)[u + vx] = au + bv$ 。用内积 $ac + bd$ 时梯度是 $a + bx$, 改用 $ac + 4bd$ 时则为 $a + (b/4)x$ 。两个梯度表示相同的线性读取, 但“最陡方向”所依据的长度不同。若梯度非零, Cauchy-Schwarz 表明单位范数方向中 $h = -\nabla_{\mathcal{H}} J(f)/\|\nabla_{\mathcal{H}} J(f)\|$ 使 $DJ(f)[h]$ 最小。这解释了梯度作为一阶下降方向的用途; 有限步更新能否降低目标, 还要控制线性近似之外的余项。

5.4.1.2 函数约束与最优判据

即使表示族能够逼近每个连续目标, 我们仍可能希望排除过大的函数值或过快的振荡。稠密性本身没有排除这些候选。若允许多项式次数和系数任意增长, 它既能逼近平滑趋势, 也能产生快速振荡。固定一个半径 $B \geq 0$, 考察范数球

$$\mathcal{F}_B = \{f \in \mathcal{V} : \|f\|_{\mathcal{V}} \leq B\}.$$

半径限制只有结合范数含义才有信息。 L^2 范数限制函数的平方积分, 却不直接限制导数; 前面定义的 Sobolev 范数同时限制函数值与直到某个非负

整数阶的弱导数,因而抑制快速振荡。Lipschitz 约束 $|f(x)-f(z)| \leq L|x-z|$ 则直接限制输入变化造成的输出变化。它们控制的对象不同,不能由一个较小的参数数量替代。

在 RKHS 中,式(5.17)说明核对角有界时,核范数球统一控制点值。两个输入之间还有

$$|f(x) - f(z)| \leq \|f\|_{\mathcal{H}_K} \|K_x - K_z\|_{\mathcal{H}_K}, \quad (5.24)$$

而

$$\|K_x - K_z\|_{\mathcal{H}_K}^2 = K(x, x) + K(z, z) - 2K(x, z).$$

因此,核既确定函数空间,也用 $\|K_x - K_z\|$ 控制两个输入处的读数最多相差多少;范数半径再限制这个差值的大小。改变核与改变正则化强度不是同一操作。

特别地,在 $\|f\|_{\mathcal{H}_K} \leq B$ 内, $|f(x)| \leq B\sqrt{K(x, x)}$, 并有 $|f(x) - f(z)| \leq B\sqrt{K(x, x) + K(z, z) - 2K(x, z)}$ 。若核连续,这给出每个函数的连续性;若右端的核距离还不超过 $L_K|x - z|$,才进一步得到 BL_K 的 Lipschitz 常数。不能从任意正定核直接推出同一种输入规则性。低秩限制控制的是可分离方向数,因子范数另外控制幅度;秩至多 r 的函数集合通常不凸,因为两个秩至多 r 的函数相加可能需要 $2r$ 个方向。

无额外约束且 J 在局部极小点 f^* 处可微时,沿任意 h 的正负扰动都可,所以 $DJ(f^*)[h] = 0$, 即 $\nabla_{\mathcal{H}} J(f^*) = 0$ 。这是必要条件;非凸目标的驻点未必最优,例如实数空间中的 $J(a) = -a^2$ 在零点驻定却非极小。凸目标和凸可行集允许更强的判据。

定理 5.27 凸函数优化的一阶判据 设 $C \subseteq \mathcal{H}$ 非空且凸, $f^* \in C$, J 在 f^* 的开邻域内 Fréchet 可微且在 C 上为有限凸函数。则 f^* 在 C 上全局最优, 当且仅当

$$\langle \nabla_{\mathcal{H}} J(f^*), g - f^* \rangle_{\mathcal{H}} \geq 0 \quad (g \in C). \quad (5.25)$$

证明. 若 f^* 最优, 凸性使 $f^* + t(g - f^*)$ 在 $0 < t \leq 1$ 时可行。目标差非负, 除以 t 再令 $t \downarrow 0$, 便得必要性。反过来, 由目标凸性,

$$J(g) - J(f^*) \geq \frac{J(f^* + t(g - f^*)) - J(f^*)}{t}.$$

令 $t \downarrow 0$, 右侧趋于 $DJ(f^*)[g - f^*]$, 再用所给不等式可得 $J(g) \geq J(f^*)$ 。■

对 $J(g) = \frac{1}{2}\|g - f\|^2$, 这个判据恰是投影定理中的变分不等式。定理刻画已经给定的可行点是否最优, 没有单独保证最优解存在。非凸低秩可行集上的两点连线未必可行, 不能照搬上述必要充分判据。

约束 $\|f\| \leq B$ 与惩罚 $\lambda\|f\|^2$ 也不应混用。前者划定可行函数，后者允许整个空间中的函数参与竞争，只是提高大范数函数的代价。若 $\lambda > 0$ 且某个惩罚问题有有限目标值的解 f_λ ，则它也是半径 $B = \|f_\lambda\|$ 对应约束问题的一个解；否则范数不更大、拟合更好的函数会降低惩罚目标。反方向要把给定半径对应到某个乘子，需另有凸性、适当可行性等条件。第4章的一阶判优思路可以这样回用，但有限维 KKT 条件、闭有界集的紧性和迭代收敛保证不能原样搬来；梯度迭代还要核对空间中的光滑性等条件。

5.4.2 有限读取下的函数优化

如果拟合项只使用有限个读数，未被这些读数看见的方向能否删去？如果删去这些方向不改变观测读数，也不会增大范数惩罚，就没有必要保留它们。不过，整个目标仍可能依赖整个函数的范数。因此“有限读取”只描述拟合项：两个函数即使在观测位置读数相同，总目标也可能因范数不同而不同。

5.4.2.1 有限表示与最优解

RKHS 可能无限维，但训练数据只给出有限个输入 $x_1, \dots, x_n$ 。拟合项只关心这些点的读数；由再生性质，与 K_{x_i} 全部正交的部分在这些点都取零，所以对拟合没有贡献。若范数惩罚随范数增加而不减，删去这一部分也不会增加惩罚。这就是有限表示定理的核心思路⁶。

⁶ B. Schölkopf, R. Herbrich, A. J. Smola, *A Generalized Representer Theorem In Computational Learning Theory*, 2001, pp. 416–426

定理 5.28 有限样本表示定理 设 $\mathcal{H}_K$ 是 $\mathcal{X}$ 上的 RKHS，训练输入为 $x_1, \dots, x_n$ 。令 $\Phi: \mathbb{R}^n \rightarrow (-\infty, \infty]$ 为任意函数， $\Omega: [0, \infty) \rightarrow (-\infty, \infty]$ 单调不减。考虑

$$\inf_{f \in \mathcal{H}_K} \{\Phi(f(x_1), \dots, f(x_n)) + \Omega(\|f\|_{\mathcal{H}_K})\}. \quad (5.26)$$

若该问题存在最优解，则至少有一个最优解具有形式

$$f^* = \sum_{i=1}^n a_i K_{x_i}. \quad (5.27)$$

若该问题的最优值有限且 Ω 严格递增，则每个最优解都具有式 (5.27) 的形式。

证明. 记 $M = \text{span}\{K_{x_1}, \dots, K_{x_n}\}$ 。这是有限维子空间，因而闭。由投影定理，任意 $f \in \mathcal{H}_K$ 都可唯一分解为

$$f = f_M + f_\perp, \quad f_M \in M, \quad f_\perp \perp M.$$

对每个训练输入 x_i , 再生性质给出

$$f(x_i) = \langle f_M, K_{x_i} \rangle + \langle f_{\perp}, K_{x_i} \rangle = f_M(x_i).$$

因此经验项 Φ 无法区分 f 与 f_M 。另一方面, 正交分解给出

$$\|f\|_{\mathcal{H}_K}^2 = \|f_M\|_{\mathcal{H}_K}^2 + \|f_{\perp}\|_{\mathcal{H}_K}^2,$$

故 $\|f_M\| \leq \|f\|$ 。当 Ω 单调不减时, 用 f_M 替换 f 不会增大目标值。若原问题存在最优解, 对任一最优解作此替换便得到 M 中的最优解, 也就是式(5.27)。

若最优值有限、 Ω 严格递增且 $f_{\perp} \neq 0$, 则 $\|f_M\| < \|f\|$, 经验项不变而惩罚项严格减小, 与 f 最优矛盾。这里最优目标值有限保证经验项与惩罚项都是有限值, 因而惩罚项的严格下降确实使总目标严格下降。所以每个最优解都必须满足 $f_{\perp} = 0$ 。 ■

定理没有证明式(5.26)必定达到下确界。存在性仍要另外证明: 最小化序列是否有收敛的子列, 极限是否可行, 目标值比较是否能传到极限。无限维中, 单凭目标下半连续且强制、可行域闭, 还不能直接套用有限维的紧性证明。它也没有保证系数向量 $(a_1, \dots, a_n)^T$ 唯一; 若 Gram 矩阵奇异, 不同系数可能表示同一个函数。单调不减惩罚只保证存在一个有限展开最优解; 只有当最优值有限且惩罚严格递增时, 才能排除每个最优解中的非零正交余项。若损失还依赖导数、积分或训练点之外的其他有界线性泛函, 表示空间应加入这些泛函的 Riesz 表示元, 不能仍机械地只写训练点核截面。

这一推广可以直接从证明读出。若拟合项为 $\Phi(L_1 f, \dots, L_n f)$, 其中 L_i 是 $\mathcal{H}$ 上的有界线性泛函, 令 h_i 为各自的 Riesz 表示元, 再取 $M = \text{span}\{h_i\}$ 。对 $f_{\perp} \perp M$, $L_i(f_{\perp}) = \langle f_{\perp}, h_i \rangle = 0$, 其余范数比较完全不变。一般的积分读取与系数读取因此也有有限表示; 导数读取则必须先验证它在所选空间有界。

5.4.2.2 有限参数化与求解

写 $f = \sum_{j=1}^n a_j h_j$, 令 $\mathbf{a} = (a_1, \dots, a_n)^T$, 定义 Gram 矩阵 $\mathbf{G} \in \mathbb{R}^{n \times n}$, $G_{i,j} = \langle h_j, h_i \rangle_{\mathcal{H}}$, 则

$$(L_1 f, \dots, L_n f)^T = \mathbf{G} \mathbf{a}, \quad \|f\|_{\mathcal{H}}^2 = \mathbf{a}^T \mathbf{G} \mathbf{a}.$$

有限表示定理将原问题的下确界化为

$$\inf_{\mathbf{a} \in \mathbb{R}^n} \left\{ \Phi(\mathbf{G} \mathbf{a}) + \Omega\left(\sqrt{\mathbf{a}^T \mathbf{G} \mathbf{a}}\right) \right\}. \quad (5.28)$$

点值读取时 $h_i = K_{x_i}$ 、 $G_{i,j} = K(x_i, x_j)$ ，即通常的核矩阵。一般读取则仍用相应表示元的 Gram 矩阵，而不是把所有观测都改称点值。有限化之后可以按目标的光滑性、凸性和约束回用第4章的方法；表示定理本身没有指定某个数值算法。

平方损失给出可直接核对的实例：

$$J(f) = \frac{1}{n} \sum_{i=1}^n (L_i f - y_i)^2 + \lambda \|f\|_{\mathcal{H}}^2, \quad \lambda > 0.$$

其中 y_i 是第 i 个读取的目标值， $\mathbf{y} = (y_1, \dots, y_n)^\top$ 。将读数和范数代入后，系数目标为 $n^{-1} \|\mathbf{G}\mathbf{a} - \mathbf{y}\|_2^2 + \lambda \mathbf{a}^\top \mathbf{G}\mathbf{a}$ ，对 $\mathbf{a}$ 求导并约去因子 $2/n$ ，驻点条件为 $\mathbf{G}((\mathbf{G} + n\lambda \mathbf{I}_n)\mathbf{a} - \mathbf{y}) = 0$ 。由于 $\mathbf{G}$ 半正定， $\mathbf{G} + n\lambda \mathbf{I}_n$ 正定，故可先解

$$(\mathbf{G} + n\lambda \mathbf{I}_n)\mathbf{a} = \mathbf{y}$$

得到一个最优系数。目标在 f 上严格凸，因而函数解唯一；但若 $\mathbf{G}$ 奇异，给 $\mathbf{a}$ 加任意 $\mathbf{v} \in \ker \mathbf{G}$ 不会改变函数，因为 $\|\sum_i v_i h_i\|^2 = \mathbf{v}^\top \mathbf{G} \mathbf{v} = 0$ 。所以这个可逆的移位方程只选出了一个系数代表，并未使原系数目标的全部最优系数唯一。若 h_i 线性无关，Gram 矩阵正定，表示系数才唯一。

这也与函数微分吻合。把 $L_i h = \langle h, h_i \rangle$ 代入目标的一阶变化，可得

$$\nabla_{\mathcal{H}} J(f) = \frac{2}{n} \sum_{i=1}^n (L_i f - y_i) h_i + 2\lambda f.$$

梯度为零时， f 必在读取方向的张成空间内。这次计算依赖可微平方损失；表示定理的正交分解证明则不要求 Φ 可微或凸。

示例 5.29 两个点值的有限求解 在 $[-1, 1]$ 的仿射 RKHS 中，取 $x_1 = -1, x_2 = 1$ ，目标值 $y_1 = 0, y_2 = 2$ ，并令 $\lambda = 1$ 。核矩阵为 $\mathbf{K} = 2\mathbf{I}_2$ ，移位方程为 $4\mathbf{a} = (0, 2)^\top$ ，得到 $\mathbf{a} = (0, 1/2)^\top$ 及 $f^*(x) = (1+x)/2$ 。也可直接令 $f(x) = a + bx$ ，把目标展开为

$$\frac{1}{2}((a-b)^2 + (a+b-2)^2) + a^2 + b^2 = 2(a-1/2)^2 + 2(b-1/2)^2 + 1.$$

所以函数解确为 $a = b = 1/2$ ，最优目标值为 1。若再使用 $x_3 = 0$ ，则三个核截面满足 $K_{-1} - 2K_0 + K_1 = 0$ ；函数仍只有两个独立方向，按输入顺序 $(-1, 1, 0)$ 排列的三项展开系数因而可以沿 $(1, 1, -2)^\top$ 变化而不改变函数。

存在性要在正确的空间里检查。上述平方损失目标连续，且 $J(f) \geq \lambda \|f\|^2$ ；在有限维 M 中，最小化序列有界，可抽出收敛子列并由连续性取得最小值。投影不增加目标，所以这也是全空间最小值。更一般地，若 $J|_M$

下半连续、某处有限且强制，即 $\|f\| \rightarrow \infty$ 时 $J(f) \rightarrow +\infty$ ，同样可用有限维紧性。不必要求冗余系数空间中的目标强制，因其零空间方向可能无界却代表同一个函数。反例是非零读取 L 对应的 $J(f) = e^{-L(f)}$ 、无范数惩罚：下确界为零，没有任何函数达到它。有限表示没有替代存在性。

附加约束 C 时还要检查 $P_M(C) \subseteq C$ 。核范数球满足这一点，只依赖同一组读数的约束也满足，因为投影不改变读数。一般约束则未必：在仿射 RKHS $f(x) = a + bx$ 中，只读取 $f(0) = a$ ，故 $M = \text{span}\{1\}$ ；约束 $b = 1$ 却使任何可行函数的投影都不可行。若目标为 $a^2 + \lambda(a^2 + b^2)$ ，约束解是 $f(x) = x$ ，确实不在 M 内。这里可以把系数读取 $b = \langle f, x \rangle$ 的表示方向 x 加入 M ，再检查投影保留约束。一般导数限制或非凸低秩限制不一定有这种有限补充，不能直接沿用无约束表示公式。

5.4.3 整体误差下的函数优化

在上一节的单调范数惩罚和投影可行条件下，有限读数看不见的方向可以被删去；整体积分误差则会同时比较许多空间方向。在 Mercer 条件下，核的谱坐标恰好把平方积分误差与核范数写成可逐项比较的和。这里的测度 μ 已指定，不是从有限训练点自动得到的。

5.4.3.1 谱正则化与最优系数

给定 $y \in L^2(\mu)$ ，紧自伴谱分解将其写为

$$y = y_0 + \sum_{j: \mu_j > 0} c_j \psi_j, \quad y_0 \in \ker T_K, \quad \|y\|_2^2 = \|y_0\|_2^2 + \sum_j c_j^2.$$

RKHS 中的函数没有 y_0 方向，故这一分量会留下不可消除的误差。考虑

$$\min_{f \in \mathcal{H}_K} \left\{ \|f - y\|_{L^2(\mu)}^2 + \lambda \|f\|_{\mathcal{H}_K}^2 \right\}, \quad \lambda > 0.$$

写 $f = \sum_j b_j \psi_j$ ，并要求 $\sum_j b_j^2 / \mu_j < \infty$ ，目标成为

$$J(f) = \|y_0\|_2^2 + \sum_j \left((b_j - c_j)^2 + \lambda \frac{b_j^2}{\mu_j} \right).$$

每个方向的二次式可配方为

$$(b_j - c_j)^2 + \frac{\lambda}{\mu_j} b_j^2 = \left(1 + \frac{\lambda}{\mu_j} \right) \left(b_j - \frac{\mu_j}{\mu_j + \lambda} c_j \right)^2 + \frac{\lambda}{\mu_j + \lambda} c_j^2.$$

因而候选最优系数为

$$b_j^* = \frac{\mu_j}{\mu_j + \lambda} c_j. \quad (5.29)$$

还必须确认逐项最优值拼成合法函数。由 $\mu_j/(\mu_j + \lambda)^2 \leq 1/(4\lambda)$, 有

$$\sum_j \frac{(b_j^*)^2}{\mu_j} = \sum_j \frac{\mu_j c_j^2}{(\mu_j + \lambda)^2} \leq \frac{1}{4\lambda} \sum_j c_j^2 < \infty.$$

所以 $f^* \in \mathcal{H}_K$ 。对有限部分和使用配方, 再以非负级数取极限, 得到

$$J(f) = J(f^*) + \sum_j \left(1 + \frac{\lambda}{\mu_j}\right) (b_j - b_j^*)^2, \quad J(f^*) = \|y_0\|_2^2 + \sum_j \frac{\lambda}{\mu_j + \lambda} c_j^2.$$

这同时证明存在、最优和唯一, 而不只是写出形式驻点。若 $K = 0$, 核空间只有零函数, 空和仍给出 $f^* = 0$ 。若令 $\lambda = 0$, 核范数可和性不再由上界保证; 正谱部分的目标若不属于 RKHS, 下确界可能只能由有限截断逼近, 不能直接把公式延伸为一个空间内最优解。特征值远小于 λ 的方向被强烈收缩, 特征值远大于 λ 的方向则大体保留。这与第4章的二次正则化是同一逐方向机制; 定理 5.28 的有限表示处理训练点目标, 这里的谱解则处理总体 $L^2(\mu)$ 目标, 两者不能省略各自的存在条件而互相替代。

附加约束后, 配方仍成立, 却未必能逐方向独立取极小值。例如要求 $\|f\|_{\mathcal{H}_K} \leq B$ 会把所有系数通过 $\sum_j b_j^2/\mu_j \leq B^2$ 耦合; 若无约束解超出球, 需要重新满足此条件。点值等式 $f(x_0) = a$ 则成为 $\sum_j b_j \psi_j(x_0) = a$, 同样联系各个方向。不能先独立收缩再宣称结果自动满足任意函数约束。

仿射核再次给出有限的核对实例。取 $K(x, z) = 1 + xz$, $d\mu(x) = dx/2$ 和目标 $y(x) = x^2$ 。其正谱系数为 $c_1 = 1/3, c_2 = 0$, 零空间分量为 $y_0 = x^2 - 1/3$, 且 $\|y_0\|_2^2 = 1/5 - 1/9 = 4/45$ 。因此

$$f^*(x) = \frac{1}{3(1+\lambda)}, \quad J(f^*) = \frac{4}{45} + \frac{\lambda}{9(1+\lambda)}.$$

第一项是仿射空间不能表示二次曲线留下的误差, 第二项来自正则化对常数方向的收缩。令 $\lambda \downarrow 0$ 时得到均匀权重下的最佳常数 $1/3$, 与前面加权投影的直接计算一致。图 5.8 则展示有无限多个方向时, 同一个收缩因子怎样随方向变化。




图 5.8 教学谱 $\mu_j = j^{-2}$ 上的收缩比例 $\mu_j/(\mu_j + \lambda)$ 。蓝、红线使用 $\lambda = 0.01$ 和 0.1 ，点标出前 25 个方向；增大正则化后更多方向被抑制。有效维度的定义仍对全部谱方向求和。

5.4.3.2 正则尺度与有效维度

正则化后，每个方向只保留原系数的 $\mu_j/(\mu_j + \lambda)$ 。当空间有无穷多个方向时，按这个保留比例合计，相当于还有多少个方向参与拟合？这给出有效维度。不过，无穷多项的和未必有限，必须先说明求和条件；迹类算子提供了相应的有限性语言。

定义 5.30 迹类条件与有效维度 设 A 为 Hilbert 空间上的紧线性算子。 A^*A 的正特征值开方后得到奇异值 $s_j(A)$ ，按重数排列；若只有有限个，可在其后补零。若 $\sum_j s_j(A) < \infty$ ，称 A 为迹类算子 (trace-class operator)。对正算子，这等价于非负特征值之和有限，它的迹就是这个和。

若紧正算子 T_K 的正特征值为 (μ_j) ，给定 $\lambda > 0$ ，其有效维度 (effective dimension) 定义为

$$d_{\text{eff}}(\lambda) = \sum_{j: \mu_j > 0} \frac{\mu_j}{\mu_j + \lambda}, \quad (5.30)$$

这里要求右侧级数有限；等价地，

$$d_{\text{eff}}(\lambda) = \text{tr}(T_K(T_K + \lambda I)^{-1})$$

并要求 $T_K(T_K + \lambda I)^{-1}$ 为迹类。

这里 I 是恒等算子。 $T_K + \lambda I$ 在正谱方向上乘以 $\mu_j + \lambda$ ，在零空间上乘以 λ ，故其逆存在且范数不超过 $1/\lambda$ ；复合算子在正谱方向上乘以 $\mu_j/(\mu_j + \lambda)$ ，

在零空间上为零，所以迹表达与级数表达相同。迹类要求有限的谱总量，有效维度则先按尺度收缩各方向，再汇总它们的贡献。在上述 Mercer 条件下， $\sum_j \mu_j < \infty$ ，所以 $d_{\text{eff}}(\lambda) \leq \lambda^{-1} \sum_j \mu_j < \infty$ 。每个谱方向按其相对于 λ 的大小贡献 0 到 1 之间的量。 $\mu_j \gg \lambda$ 的方向近似贡献 1， $\mu_j \ll \lambda$ 的方向贡献很小。有限样本 Gram 矩阵也有对应量

$$\text{tr}(\mathbf{K}(\mathbf{K} + n\lambda\mathbf{I}_n)^{-1}),$$

但它依赖当前输入与归一化约定，不应和总体积分算子的 $d_{\text{eff}}(\lambda)$ 混为同一数值。

以仿射核的两个正特征值 $1, 1/3$ 为例， $d_{\text{eff}}(\lambda) = 1/(1+\lambda) + 1/(1+3\lambda)$ 。在 $\lambda = 1$ 时它等于 $3/4$ ，虽然 RKHS 的代数维数仍是 2。对图中的无限谱 $\mu_j = j^{-2}$ ，各项为 $1/(1+\lambda j^2)$ ，由收敛的 $\sum_j j^{-2}$ 可知每个 $\lambda > 0$ 下总和有限。只有紧性还不够：在 ℓ^2 上定义 $T\mathbf{e}_j = j^{-1}\mathbf{e}_j$ ，其有限截断按算子范数收敛到 T ，故 T 紧且为正，但 $\sum_j 1/(1+\lambda j)$ 发散，不能给出有限有效维度。

有效维度不是代数维数。无限维空间在固定 λ 下可以有有限有效维度；反过来，一个有限参数化若参数到函数的映射高度敏感，也可能形成很大的函数集合。参数数量、谱衰减、导数规则性和范数半径从不同方面描述复杂度。后续核正则化会同时使用谱和范数；神经切线核只在相应线性化条件下提供这种空间解释，深层网络本身的复杂度不能无条件等同于某个固定核的有效维度。有效维度也不是覆盖数：前者由算子谱与 λ 汇总收缩比例，后者还指定函数类的半径、误差距离和覆盖精度，计算需要多少代表。有效维度的定义没有指定待覆盖的函数类或允许误差，因此不能单独回答需要多少代表函数，也不能单独保证统计误差。

5.5 本章小结

沿 $f_\star(x) = |x - 1/2|$ 的拟合问题回看本章，第一步不是选择多少参数，而是决定允许哪些函数、用什么误差比较它们。连续函数配一致范数可以控制全域最大误差； L^2 强调测度加权的整体误差；Sobolev 空间把弱导数纳入比较；RKHS 另要求点值稳定。赋范与内积规定距离和正交，完备性保证柯西极限留在空间内，二者不能混为一个条件。闭凸投影再把这些结构用于最佳近似，权重改变时，最佳函数也可能改变。

固定折点目标可以被多项式逐步逼近，也可以被合适的样条或两个 ReLU 单元精确表示。这是对一个目标的表示能力；整个函数类是否能由有限个代表覆盖，必须另查距离、幅度与精度。无限维闭范数球不自动有有限覆盖，稠密子集也不自动提供统一的有限近似。查询树则把确定性近似扩展到输入依赖过去分支的场景，不在树结构中暗含概率或在线保证。

算子说明函数怎样被读取和变换。有界读取可由 Riesz 表示为内积，稳定点值由此产生核截面；任意正定核反过来先把零距离的表示视为同一对象，再补入柯西极限，构造出 RKHS。选定测度以后，积分算子的谱提供整体方向；Mercer 的处处一致展开还依赖连续性、紧度量域和全支撑测度，不是有限 Gram 矩阵半正定性的直接改写。

真正求解拟合问题时，函数微分与梯度给出一阶变化，约束改变可行扰动和最优判据。有限读取配单调范数惩罚时，至少可以选择一个只使用读取方向的有限展开最优解，但仍需检查存在性、函数唯一性与系数唯一性；整体平方误差则在谱坐标中产生逐方向收缩，并保留零空间误差。核决定方向和范数，半径限制可行幅度，正则参数决定惩罚尺度，新增约束还可能耦合方向。这些结论区分了极限存在、表示能力与可计算求解，没有替代统计保证。第 6 章“线性空间”将系统整理有限维坐标、矩阵、投影与低秩工具；第 10 章“随机变量”再用条件期望的信息投影和推断误差，将本章的确定性结构接到相应的观测条件上。

第二部分

线性和非线性空间

Linear and Nonlinear Spaces

阅读指引

本部分研究数据与变换所在的空间。同一个对象可以有不同坐标，坐标差也未必等于实际距离。我们需要空间结构来说明怎样比较对象、衡量长度和角度，以及局部计算能否揭示整体形状。在线性空间中，全局基和矩阵提供了统一表示；在非线性空间中，一套全局坐标可能不够用，需要局部坐标和不随坐标改变的几何量。

第 6 章“线性空间”围绕向量空间、内积、线性映射和矩阵展开，连接方程求解、谱分解、低秩近似与扰动分析。矩阵在这里是线性变换的坐标表示；换基、范数和条件数共同决定数值结果如何解释。第 7 章“非线性空间与流形”用局部坐标、切空间、度量、联络和曲率描述弯曲空间，并讨论对称性、拓扑关系及流形上的优化。

两章共享“对象—表示—变换—稳定性”这组问题。线性空间允许用全局基和矩阵统一处理，流形通常只能在局部线性化；局部切空间能够复用线性工具，却不能代替曲率、拓扑和全局可达性的判断。

线性空间

设想一个线性模型使用两项几乎重复的特征。给定系数，计算预测并不难；但给定预测值，反求系数时却可能得到两个很大、相互抵消的数，轻微的数据误差也可能使它们大幅变化。我们因此需要回答三个问题：这两项特征怎样共同表示预测，怎样从预测反求系数，以及能否舍弃近乎重复的方向来压缩模型。若模型还用于逐步更新状态，就要进一步分析反复应用同一个变换的结果。每项任务都要说明所求对象、误差怎样衡量，以及数据误差和计算舍入怎样影响结果；仅会按规则乘矩阵，还不足以回答这些问题。

本章用一组近共线特征贯穿表示、求解、压缩与误差分析：

$$\mathbf{X}_\varepsilon = \begin{bmatrix} 1 & 1 \\ 1 & 1 + \varepsilon \\ 1 & 1 - \varepsilon \end{bmatrix} = [\mathbf{c}_1 \quad \mathbf{c}_2], \quad \mathbf{q} = \begin{bmatrix} 0 \\ 1 \\ -1 \end{bmatrix}, \quad \mathbf{c}_2 = \mathbf{c}_1 + \varepsilon \mathbf{q}. \quad (6.1)$$

这里 $\mathbf{c}_1 = (1, 1, 1)^\top$ 。当 $\varepsilon \neq 0$ 时两列线性无关，但 $|\varepsilon|$ 很小时它们几乎同向，这称为近共线（nearly collinear）。“近”指作为输出空间中向量的两列接近同一方向，不是说各个样本点彼此接近。我们将看到：两列几乎重复时，拟合值可以相当稳定，表示它的两个系数却可能很大。

第5章已经建立空间、范数、投影与伴随的通用语言。本章把它们落实到有限坐标，并依次回答怎样表示输入到输出的变换、怎样反求输入、怎样计算反复作用的结果、怎样压缩存储与计算，以及怎样判断答案可靠。特征分解和奇异值分解各自在需要它们的任务中出现；反复作用另用一个固定的二维方阵，不对矩形设计矩阵 $\mathbf{X}_\varepsilon$ 强行取幂。

6.1 线性对象的空间与表示

描述一个对象，需要先确定哪些对象可以相加，再选择记录它的坐标，最后说明怎样比较两个对象的差异。这三项设定不能互相代替：相同的数值列表可以属于不同空间，同一个对象可以有不同坐标，而同一个残差在不同几何下也可以有不同大小。

6.1.1 线性组合与对象空间

两段信号可以相加，一条曲线可以按倍数缩放，两个同形矩阵也可以逐项相加。这些对象虽然形状不同，却都能作为向量：这里关心的是相加和数乘的规则，并不要求对象天然就是一个数字列。设标量域 $\mathbb{F}$ 为 $\mathbb{R}$ 或 $\mathbb{C}$ 。向量空间 (vector space) V 对加法和数乘封闭，并满足加法交换律、结合律、零元与逆元、数乘结合律、两条分配律以及 $1\mathbf{v} = \mathbf{v}$ 。这些公理保证有限次线性运算仍有一致的意义。 $\mathbb{R}^d$ 、所有 $m \times d$ 实矩阵以及次数不超过 k 的实多项式都是例子；集合 $\{\mathbf{x} : x_1 = 1\}$ 则不是，因为它不包含零向量，也不对加法封闭。形状像直线并不是线性空间的判据。

若我们只允许某些向量参与运算，还要检查相加和数乘后是否仍在允许范围内。例如齐次线性约束的两个解相加，仍然满足约束。一般地，非空子集 $U \subseteq V$ 若满足

$$a\mathbf{u} + b\mathbf{v} \in U \quad (\mathbf{u}, \mathbf{v} \in U, a, b \in \mathbb{F}),$$

便是线性子空间 (linear subspace)。例如固定形状的有限数组在逐项加法和数乘下构成空间，满足某些齐次线性约束的数组构成其子空间。经过原点与否在这里很重要：非零平移后的子空间一般是仿射集合，不再是线性子空间。

用一组已有方向表示新对象时，首先要问哪些对象能由它们组合得到。给定 $\mathbf{v}_1, \dots, \mathbf{v}_k$ ，所有线性组合 (linear combination) $\sum_j a_j \mathbf{v}_j$ 组成张成空间 (span)

$$\text{span}\{\mathbf{v}_1, \dots, \mathbf{v}_k\} = \left\{ \sum_{j=1}^k a_j \mathbf{v}_j : a_j \in \mathbb{F} \right\}.$$

它是包含这些向量的最小子空间，回答“哪些对象能够表示”。表示是否冗余则由另一个条件判断：若

$$a_1 \mathbf{v}_1 + \dots + a_k \mathbf{v}_k = \mathbf{0} \quad (6.2)$$

仅在全部 $a_j = 0$ 时成立，就称这组向量线性无关 (linearly independent)。否则挑出一个非零系数并移项，就能把相应向量写成其余向量的线性组合。

在贯穿例中，

$$a_1 \mathbf{c}_1 + a_2 \mathbf{c}_2 = (a_1 + a_2) \mathbf{c}_1 + a_2 \varepsilon \mathbf{q}.$$

若这个线性组合等于零， $\mathbf{c}_1$ 与 $\mathbf{q}$ 的线性无关性就要求 $a_1 + a_2 = 0$ 且 $a_2 \varepsilon = 0$ 。所以 $\varepsilon \neq 0$ 时只能有 $a_1 = a_2 = 0$ ； $\varepsilon = 0$ 时却有 $\mathbf{c}_1 - \mathbf{c}_2 = \mathbf{0}$ 。两列接近同向并不等于线性相关：前者描述它们接近相关的程度，后者判断是否存在精确的非零系数组合得到零。

有限维空间的一组无冗余生成向量称为**基** (basis)，即同时满足张成和线性无关。基的向量数为**维数** (dimension) $\dim V$ 。从任一有限生成组中反复删除冗余成员就能得到基；线性无关组也能逐次加入不在其张成空间中的向量，直至扩充成基。不同基具有相同大小：若一组有 r 个无关向量，另一组有 s 个生成向量，逐次用前一组替换后一组中的向量而保持张成，可得 $r \leq s$ ；交换两组又得 $s \leq r$ 。这一有限维结论支持后面的基扩充和维数计算，不直接推广到无限维函数展开。

有时需要保留一组方向，有时则恰好要忽略它们。前者用子空间表示；后者把沿这些方向移动后无法区分的对象视为一类。

定义 6.1 线性空间的商空间 设 N 为 V 的线性子空间。规定 $\mathbf{x} \sim \mathbf{y}$ 当且仅当 $\mathbf{x} - \mathbf{y} \in N$ ，等价类 $\mathbf{x} + N = \{\mathbf{x} + \mathbf{n} : \mathbf{n} \in N\}$ 组成商空间 (quotient space) V/N ，其运算为

$$(\mathbf{x} + N) + (\mathbf{y} + N) = (\mathbf{x} + \mathbf{y}) + N, \quad a(\mathbf{x} + N) = a\mathbf{x} + N.$$

若换代表元 $\mathbf{x}' = \mathbf{x} + \mathbf{n}_1$ 、 $\mathbf{y}' = \mathbf{y} + \mathbf{n}_2$ ，结果只相差 $\mathbf{n}_1 + \mathbf{n}_2$ 或 $a\mathbf{n}_1$ ，仍属于 N ，所以运算不依赖代表元。例如 $N = \text{span}\{(0, 1)^\top\} \subset \mathbb{R}^2$ 时，每条竖直直线是一个等价类，商空间只记录第一坐标。取 N 的基并扩充为 V 的基，新增基向量的等价类构成 V/N 的基，因而 $\dim(V/N) = \dim V - \dim N$ 。后面反求输入时，也会遇到这种情形：若一个变换把 N 中的所有方向映为零，两个相差 N 中向量的输入就会产生同一个输出。

6.1.2 基与坐标组织

固定有序基 $\mathcal{B} = (\mathbf{b}_1, \dots, \mathbf{b}_d)$ 后，对象 $\mathbf{v}$ 唯一写成 $\sum_j x_j \mathbf{b}_j$ 。系数列 $[\mathbf{v}]_{\mathcal{B}} = (x_1, \dots, x_d)^\top$ 称为**坐标** (coordinates)。存在性来自张成；两组表示相减得到式 (6.2)，线性无关性保证唯一性。在 $\mathbb{R}^d$ 中直接写数字列，通常是默认使用标准基 $\mathbf{e}_1, \dots, \mathbf{e}_d$ 。函数基展开也完全如此：函数是对象，展开系数是坐标。

对象不变时，坐标仍可能很不一样。固定 $\delta = 0.1$ 并令

$$\mathbf{y} = \mathbf{c}_1 + \delta \mathbf{q} = \begin{bmatrix} 1 \\ 1.1 \\ 0.9 \end{bmatrix}. \quad (6.3)$$

在 $\mathcal{B}_0 = (\mathbf{c}_1, \mathbf{q})$ 下坐标是 $(1, \delta)^\top$ 。若 $\varepsilon \neq 0$ ，改用同一平面上的基 $\mathcal{B}_\varepsilon = (\mathbf{c}_1, \mathbf{c}_2)$ ，则

$$\mathbf{y} = \left(1 - \frac{\delta}{\varepsilon}\right) \mathbf{c}_1 + \frac{\delta}{\varepsilon} \mathbf{c}_2. \quad (6.4)$$

$\varepsilon = 0.01$ 时坐标成为 $(-9, 10)^\top$ ，但 $\mathbf{y}$ 没有改变。两个很大的系数在几乎同向的基向量上相消，不能据此判断原对象很大。

若 $\mathcal{C}$ 是另一组基，把各 $\mathbf{b}_j$ 的 $\mathcal{C}$ 坐标排成列，得到换基矩阵 $\mathbf{S}_{\mathcal{C} \leftarrow \mathcal{B}}$ 。保持线性组合给出

$$[\mathbf{v}]_{\mathcal{C}} = \mathbf{S}_{\mathcal{C} \leftarrow \mathcal{B}} [\mathbf{v}]_{\mathcal{B}}. \quad (6.5)$$

沿反方向换基能恢复原坐标，两个坐标变换互逆。在上例中

$$\mathbf{S}_{\mathcal{B}_0 \leftarrow \mathcal{B}_\varepsilon} = \begin{bmatrix} 1 & 1 \\ 0 & \varepsilon \end{bmatrix}.$$

反向求坐标要除以 ε ，已经提示小扰动可能被放大。此处改变的是记录方式，不是对对象施加了一个新的物理变换。

一个批次包含多个样本，每个样本又包含多个位置，每个位置有一组特征。把所有数摊成一长列虽然不丢信息，却很难看出哪个数属于哪个样本或位置。使用多个索引可以保留这些分组关系。

定义 6.2 多维数值数组 给定正整数 $n_1, \dots, n_k$ ，形状为 $n_1 \times \dots \times n_k$ 的数值数组，是从 $\{1, \dots, n_1\} \times \dots \times \{1, \dots, n_k\}$ 到 $\mathbb{F}$ 的映射。第 j 个索引称为第 j 个轴，轴数 k 称为数组的阶。机器学习中常将这样的数组称为张量 (tensor)。

例如 $\mathbf{X} \in \mathbb{R}^{b \times \ell \times d}$ 可以记录 b 个样本、每个样本 ℓ 个位置和每个位置 d 个特征； $x_{i,j,k}$ 由三个索引共同定位。固定部分索引所得对象称为切片，例如 $\mathbf{X}_{i,:,:}$ 保留第 i 个样本， $\mathbf{X}_{:,j,k}$ 保留指定位置、指定特征在全部样本上的数值。数组阶数是轴数，不是矩阵秩。

维度重排 (permutation of axes) 改变轴的顺序。例如 $y_{i,k,j} = x_{i,j,k}$ 把 $b \times \ell \times d$ 变为 $b \times d \times \ell$ 。**形状重整** (reshape) 则先指定元素的遍历顺序，再把同一数列装入另一形状；仅要求元素总数相同。以 $\mathbf{A} = \begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \end{bmatrix}$ 为例，轴交换得到 $\mathbf{A}^\top = \begin{bmatrix} 1 & 4 \\ 2 & 5 \\ 3 & 6 \end{bmatrix}$ ，按行读取后重整成 3×2 得到 $\begin{bmatrix} 1 & 2 \\ 3 & 4 \\ 5 & 6 \end{bmatrix}$ ，两者不同。所以重整不能只给目标形状，还要给顺序。

本章统一用按列堆叠的向量化 (vectorization)：

$$\text{vec}(\mathbf{A}) = (a_{1,1}, \dots, a_{m,1}, a_{1,2}, \dots, a_{m,n})^\top, \quad \mathbf{A} \in \mathbb{F}^{m \times n}.$$

元素 $a_{i,j}$ 对应索引 $i + (j-1)m$ 。例如上述 $\mathbf{A}$ 的向量化为 $(1, 4, 2, 5, 3, 6)^\top$ 。这种编码保留全部信息；是否表示输入输出关系，还要看下一节指定的映射，不能从“它是一张矩阵”直接推出。

数值数组也不自动成为几何中的张量对象。后者还规定各坐标轴怎样换基共同变换，使不同分量表代表同一个多线性对象。这里只需要数组

及其索引规则；高阶张量分解的各种秩也不共享矩阵秩的一套结论。区分这些用法，才能避免把存储格式当成几何性质。

6.1.3 内积与误差几何

坐标确定了怎样记录差异，却没有确定差异的代价。实坐标沿用此前的内积约定 $\langle \mathbf{x}, \mathbf{y} \rangle = \mathbf{x}^\top \mathbf{y}$ ；扩展到复坐标时，本章取 $\langle \mathbf{x}, \mathbf{y} \rangle = \mathbf{x}^* \mathbf{y}$ ，对第一个变量共轭线性、第二个变量线性。这里 $\mathbf{A}^* = \overline{\mathbf{A}}^\top$ 为共轭转置，实数情形退化为转置。内积必须共轭对称、正定，并诱导范数

$$\|\mathbf{x}\| = \sqrt{\langle \mathbf{x}, \mathbf{x} \rangle}. \quad (6.6)$$

两个向量的内积为零，就称它们正交（orthogonal）。要用内积控制误差，首先需要下面的不等式；随后再把它推广到不同的坐标范数。

定理 6.3 Cauchy-Schwarz 不等式 在实或复内积空间中， $|\langle \mathbf{x}, \mathbf{y} \rangle| \leq \|\mathbf{x}\| \|\mathbf{y}\|$ 。等号成立当且仅当两向量线性相关。

证明. $\mathbf{y} = \mathbf{0}$ 时直接成立。否则令 $a = \langle \mathbf{y}, \mathbf{x} \rangle / \|\mathbf{y}\|^2$ ，则

$$0 \leq \|\mathbf{x} - a\mathbf{y}\|^2 = \|\mathbf{x}\|^2 - \frac{|\langle \mathbf{x}, \mathbf{y} \rangle|^2}{\|\mathbf{y}\|^2}.$$

移项即得不等式；等号恰好要求 $\mathbf{x} = a\mathbf{y}$ 。 ■

实空间中非零向量的夹角由 $\cos \theta = \langle \mathbf{x}, \mathbf{y} \rangle / (\|\mathbf{x}\| \|\mathbf{y}\|)$ 定义；复内积可能非实，不能直接沿用这一实夹角公式。在贯穿例中 $\mathbf{c}_1^\top \mathbf{q} = 0$ 、 $\|\mathbf{c}_1\|_2^2 = 3$ 、 $\|\mathbf{c}_2\|_2^2 = 3 + 2\varepsilon^2$ ，因此

$$\cos \theta_\varepsilon = \frac{\sqrt{3}}{\sqrt{3 + 2\varepsilon^2}} \longrightarrow 1. \quad (6.7)$$

这给“几乎同向”一个确定的欧氏度量；更换内积也会更换角度。

范数(norm)满足正定性、绝对齐次性和三角不等式(triangle inequality)。有限坐标中常用

$$\|\mathbf{x}\|_p = \left(\sum_j |x_j|^p \right)^{1/p} \quad (1 \leq p < \infty), \quad \|\mathbf{x}\|_\infty = \max_j |x_j|.$$

其中 $p = 1$ 累加绝对偏差， $p = 2$ 将平方偏差求和后开方， $p = \infty$ 控制最大坐标偏差；距离是差向量的范数 $d(\mathbf{x}, \mathbf{y}) = \|\mathbf{x} - \mathbf{y}\|$ 。并非每个范数都来自内积。例如 ℓ_1 范数对 $\mathbf{e}_1, \mathbf{e}_2 \in \mathbb{R}^2$ 使平行四边形恒等式左侧为 8、右侧为 4，不满足式 (5.2) 的判据。

定理 6.4 有限维 Hölder 不等式 设 $1 \leq p, q \leq \infty$ 且 $1/p + 1/q = 1$, 约定 $1/\infty = 0$ 。对于标准坐标配对, $|\mathbf{x}^* \mathbf{y}| \leq \|\mathbf{x}\|_p \|\mathbf{y}\|_q$ 。

证明. 先设 $1 < p, q < \infty$ 。Young 不等式 $uv \leq u^p/p + v^q/q$ 对 $u, v \geq 0$ 成立: $u > 0$ 时令 $t = v/u^{p-1}$, 只需验证 $1/p + t^q/q - t \geq 0$; 其导数为 $t^{q-1} - 1$, 最小值在 $t = 1$ 处为零。 $u = 0$ 时也成立。若两向量非零, 取 $u_j = |x_j|/\|\mathbf{x}\|_p$, $v_j = |y_j|/\|\mathbf{y}\|_q$ 并求和, 得到 $\sum_j u_j v_j \leq 1/p + 1/q = 1$ 。恢复尺度, 再用 $|\mathbf{x}^* \mathbf{y}| \leq \sum_j |x_j| |y_j|$ 即可。零向量时两侧都为零; $p = 1, q = \infty$ 时用 $\sum_j |x_j| |y_j| \leq (\max_j |y_j|) \sum_j |x_j|$, 另一端点交换两者。■

Cauchy-Schwarz 给出 $\|\mathbf{x} + \mathbf{y}\|_2^2 \leq (\|\mathbf{x}\|_2 + \|\mathbf{y}\|_2)^2$, 从而验证欧氏三角不等式。一般 $1 < p < \infty$ 时, 将 $|x_j + y_j|^{p-1}$ 分别与 $|x_j|$ 、 $|y_j|$ 应用 Hölder, 得到

$$\|\mathbf{x} + \mathbf{y}\|_p^p \leq (\|\mathbf{x}\|_p + \|\mathbf{y}\|_p) \|\mathbf{x} + \mathbf{y}\|_p^{p-1};$$

非零时相除, 零时直接成立, 两个端点逐坐标验证。因此这些表达确实是范数。有限维范数等价只保证它们给出相同的收敛概念, 不保证误差常数相同。例如

$$\|\mathbf{x}\|_\infty \leq \|\mathbf{x}\|_2 \leq \sqrt{d} \|\mathbf{x}\|_\infty, \quad \|\mathbf{x}\|_2 \leq \|\mathbf{x}\|_1 \leq \sqrt{d} \|\mathbf{x}\|_2.$$

维数增加时 $\sqrt{d}$ 不能在误差预算中忽略。

若关心的一次线性读取 $\mathbf{z}^* \mathbf{r}$, 最坏误差还取决于读取方向 $\mathbf{z}$ 。

定义 6.5 有限维对偶范数 给定 $\mathbb{F}^d$ 上的范数, 相对于标准坐标配对的对偶范数 (dual norm) 为

$$\|\mathbf{z}\|_* = \max_{\|\mathbf{r}\| \leq 1} |\mathbf{z}^* \mathbf{r}|. \quad (6.8)$$

单位球在有限维中紧, 目标连续, 故最大值能够达到; 它满足范数公理, 因为线性读取满足三角不等式和齐次性, 且非零 $\mathbf{z}$ 总能读取某个坐标得到非零值。Hölder 给出 ℓ_p 单位球上的上界 $\|\mathbf{z}\|_q$ 。当 $1 < p < \infty$ 且 $\mathbf{z} \neq 0$ 时, 取

$$r_j = \frac{z_j}{|z_j|} \frac{|z_j|^{q-1}}{\|\mathbf{z}\|_q^{q-1}} \quad (z_j \neq 0), \quad r_j = 0 \quad (z_j = 0),$$

就有 $\|\mathbf{r}\|_p = 1$ 且 $\mathbf{z}^* \mathbf{r} = \|\mathbf{z}\|_q$ 。 $p = 1$ 时把单位预算放在 $|z_j|$ 最大的坐标, 取相同相位; $p = \infty$ 时每个非零坐标都取相同相位。因而

$$(\|\cdot\|_p)_* = \|\cdot\|_q, \quad \frac{1}{p} + \frac{1}{q} = 1, \quad (6.9)$$

并对 $\rho \geq 0$ 有

$$\max_{\|\mathbf{r}\|_p \leq \rho} |\mathbf{z}^* \mathbf{r}| = \rho \|\mathbf{z}\|_q. \quad (6.10)$$

例如 $\mathbf{z} = (2, -1)^\top$ 、 $|r_j| \leq 0.01$ 时最大变化为 0.03，由 $\mathbf{r} = (0.01, -0.01)^\top$ 达到。图 6.1 固定同一次读取，显示预算形状怎样改变最坏方向。非线性函数若只用此界控制一阶项，还必须另控余项；这里的对偶范数也不同于第 4.4.3.2 节从约束问题构造下界的拉格朗日对偶。




图 6.1 同一线性读取 $2r_1 - r_2$ 在 ℓ_1 、 ℓ_2 、 ℓ_∞ 单位球上的最大值依次为 2、 $\sqrt{5}$ 、3。虚线为最后接触可行集的支撑直线，点为最大化方向。三图坐标尺度相同，均为解析教学例；改变允许误差的形状会改变误差常数。

权重可以进一步区分不同方向的代价。复方阵 $\mathbf{M}$ 满足 $\mathbf{M}^* = \mathbf{M}$ 时称为 Hermitian 矩阵，即等于自己的共轭转置；若还对每个非零 $\mathbf{x}$ 满足 $\mathbf{x}^* \mathbf{M} \mathbf{x} > 0$ ，则称为 Hermitian 正定矩阵。这是实对称正定条件的复数对应。这样的 $\mathbf{M}$ 给出 $\langle \mathbf{x}, \mathbf{y} \rangle_{\mathbf{M}} = \mathbf{x}^* \mathbf{M} \mathbf{y}$ 和 $\|\mathbf{x}\|_{\mathbf{M}} = \sqrt{\mathbf{x}^* \mathbf{M} \mathbf{x}}$ 。若 $\mathbf{M}$ 仅半正定，配对只给半内积，诱导半范数以及

$$d_{\mathbf{M}}(\mathbf{x}, \mathbf{y}) = \sqrt{(\mathbf{x} - \mathbf{y})^* \mathbf{M} (\mathbf{x} - \mathbf{y})}. \quad (6.11)$$

半正定的 Cauchy-Schwarz 仍可从 $\langle \mathbf{x} + t\mathbf{y}, \mathbf{x} + t\mathbf{y} \rangle_{\mathbf{M}} \geq 0$ 得到，因而三角不等式保留；不同点的距离却可能为零。这是定义 3.4 的伪距离。例如 $\mathbf{M} = \text{diag}(1, 0)$ 无法区分 $(0, 0)^\top$ 和 $(0, 1)^\top$ 。后文构造 $\mathbf{M} = \mathbf{L}^* \mathbf{L}$ 后，还能把它写成 $\|\mathbf{L}(\mathbf{x} - \mathbf{y})\|_2$ ：正定时只是改变几何，退化时则消去方向。

对同形矩阵，把元素视为有限坐标，得到 Frobenius 内积 $\langle \mathbf{A}, \mathbf{B} \rangle_{\text{F}} = \sum_{i,j} \overline{a_{i,j}} b_{i,j}$ ，以及 $\|\mathbf{A}\|_{\text{F}} = (\sum_{i,j} |a_{i,j}|^2)^{1/2}$ 。这是矩阵作为对象的长度；它与矩阵把输入向量的长度最多放大多少，是两种不同的量。

几何也决定怎样将对象表示到一个较小的子空间。设 U 是有限维内积空间的子空间， $U^\perp = \{\mathbf{r} : \langle \mathbf{u}, \mathbf{r} \rangle = 0, \mathbf{u} \in U\}$ 为正交补。由定理 5.10，有

限维闭子空间上存在唯一的正交投影 (orthogonal projection), 将向量分解为 $\mathbf{y} = \hat{\mathbf{y}} + \mathbf{r}$, 其中 $\hat{\mathbf{y}} \in U$, $\mathbf{r} \in U^\perp$. 对任意 $\mathbf{u} \in U$,

$$\|\mathbf{y} - \mathbf{u}\|^2 = \|\mathbf{r}\|^2 + \|\hat{\mathbf{y}} - \mathbf{u}\|^2,$$

所以投影是唯一最近点¹. 若 $\mathbf{Q}$ 的列为 U 的标准正交基, $\mathbf{Q}^* \mathbf{Q} = \mathbf{I}$, 系数直接由内积读取:

$$\hat{\mathbf{y}} = \mathbf{Q} \mathbf{Q}^* \mathbf{y}, \quad \mathbf{P}_U = \mathbf{Q} \mathbf{Q}^*, \quad \mathbf{P}_U^* = \mathbf{P}_U, \quad \mathbf{P}_U^2 = \mathbf{P}_U. \quad (6.12)$$

标准正交基可由逐次减去已有方向的投影并归一化得到, 这就是此前的 Gram-Schmidt 正交化; 减去后为零说明原方向冗余。

若基向量不正交, 直接计算 $\langle \mathbf{b}_i, \mathbf{y} \rangle$, 会同时读到 $\mathbf{y}$ 沿其他基向量的分量。因此要先记录基向量之间的内积, 再一起求出投影系数。

定义 6.6 有限向量族的 Gram 矩阵 向量 $\mathbf{b}_1, \dots, \mathbf{b}_r$ 的 Gram 矩阵 (Gram matrix) 为 $g_{i,j} = \langle \mathbf{b}_i, \mathbf{b}_j \rangle$. 若 $\mathbf{B}$ 以它们为列, 标准坐标中 $\mathbf{G} = \mathbf{B}^* \mathbf{B}$, 加权坐标中 $\mathbf{G} = \mathbf{B}^* \mathbf{M} \mathbf{B}$.

因为 $\mathbf{a}^* \mathbf{G} \mathbf{a} = \|\sum_j a_j \mathbf{b}_j\|^2$, Gram 矩阵半正定, 且在内积正定时, 正定当且仅当这组向量线性无关。令 $\hat{\mathbf{y}} = \sum_j a_j \mathbf{b}_j$, 残差与每个 $\mathbf{b}_i$ 正交要求

$$\sum_j g_{i,j} a_j = \langle \mathbf{b}_i, \mathbf{y} \rangle.$$

这给出投影系数的线性方程, 而非一组可直接独立读取的坐标。怎样解它, 以及方向冗余时怎样选择系数, 留给第 6.3 节。

示例 6.7 同一子空间的两种最近点 在 $\mathbb{R}^2$ 中取

$$\mathbf{b} = (2, 1)^\top, \quad U = \text{span}\{(1, 1)^\top\}.$$

欧氏投影的标量系数满足 $2a = 3$, 故 $\mathbf{p} = (1.5, 1.5)^\top$. 改用 $\mathbf{M} = \text{diag}(1, 4)$, 系数满足 $5a = 6$, 得到 $\mathbf{p}_\mathbf{M} = (1.2, 1.2)^\top$. 第二坐标误差代价更大, 最近点便向 $b_2 = 1$ 靠近。残差 $(0.8, -0.2)^\top$ 与 $(1, 1)^\top$ 的普通内积非零, 加权内积却为零。

6.2 线性变换的表示、运算与函数

对象的坐标和几何已经确定, 接下来才讨论从输入到输出的规则。矩阵表示使规则能够计算, 组合产生新的规则, 范数比较它们的作用大小; 固定

¹ S. Axler, *Linear Algebra Done Right*, Springer, 2015, 3rd ed.




图 6.2 同一目标在同一直线上的欧氏投影与加权投影。实箭头是投影向量，虚线是残差；右图画在普通坐标中，残差不必形成欧氏直角。正交性必须用所选内积判断。

一个方阵后，还能由反复复合和极限定义矩阵函数。这些操作需要的条件并不相同。

6.2.1 线性变换的矩阵表示

设计矩阵把每个特征的贡献按系数相加，得到预测：输入系数相加，预测也相加；输入系数放大，预测按相同比例放大。保持这类组合规则的变换称为 **线性映射** (linear map)。一般地， $T: V \rightarrow W$ 保持线性组合： $T(a\mathbf{x} + b\mathbf{y}) = aT\mathbf{x} + bT\mathbf{y}$ ，特别有 $T\mathbf{0} = \mathbf{0}$ 。给定输入基 $\mathcal{B} = (\mathbf{b}_1, \dots, \mathbf{b}_d)$ 和输出基 $\mathcal{C}$ ，只要记录每个基向量的像就能记录整个映射。将 $[T\mathbf{b}_j]_{\mathcal{C}}$ 作为第 j 列，得到 $\mathbf{A} = [T]_{\mathcal{C} \leftarrow \mathcal{B}} \in \mathbb{F}^{m \times d}$ ，并有

$$[T\mathbf{v}]_{\mathcal{C}} = [T]_{\mathcal{C} \leftarrow \mathcal{B}} [\mathbf{v}]_{\mathcal{B}}. \quad (6.13)$$

列数是输入维数，行数是输出维数。图 6.3 中两条路径给同一结果，表明矩阵是映射在两端坐标下的表示，不是映射本身的全部含义。

设计矩阵 $\mathbf{X}_{\epsilon}$ 表示 $T_{\epsilon}: \mathbb{R}^2 \rightarrow \mathbb{R}^3$ ， $\mathbf{w} \mapsto w_1 \mathbf{c}_1 + w_2 \mathbf{c}_2$ 。输入是两个系数，输出是三个样本的拟合值，不能把它们当成同一个向量。带偏置的规则 $\mathbf{x} \mapsto \mathbf{A}\mathbf{x} + \mathbf{b}$ 在 $\mathbf{b} \neq \mathbf{0}$ 时为仿射映射。增广坐标给出

$$\begin{bmatrix} \mathbf{A} & \mathbf{b} \\ \mathbf{0}^\top & 1 \end{bmatrix} \begin{bmatrix} \mathbf{x} \\ 1 \end{bmatrix} = \begin{bmatrix} \mathbf{A}\mathbf{x} + \mathbf{b} \\ 1 \end{bmatrix}.$$

大矩阵对增广空间是线性的，但原输入被限制在未坐标为 1 的仿射集合上，不能因此声称原映射线性。




图 6.3 先作用于对象再取坐标，与先取输入坐标再乘矩阵，得到相同输出坐标。横向箭头改变对象或数值，竖向箭头只改变记录方式。

若两端新坐标分别满足 $[\mathbf{v}]_{B'} = \mathbf{S}_V[\mathbf{v}]_B$ 、 $[\mathbf{w}]_{C'} = \mathbf{S}_W[\mathbf{w}]_C$ ，记反向坐标变换为 $\mathbf{S}_V^{-1}$ ，则新矩阵是 $\mathbf{S}_W \mathbf{A} \mathbf{S}_V^{-1}$ 。只有同一空间上的算子且两端采用同一次换基时，才成为相似关系

$$\mathbf{A}_C = \mathbf{S} \mathbf{A}_B \mathbf{S}^{-1}. \quad (6.14)$$

这里的逆记号表示已知可逆的坐标对应；一般矩阵何时可逆将在求解一节建立。

定义 5.22 的伴随把输出端的线性配对搬回输入端：

$$\langle T\mathbf{x}, \mathbf{y} \rangle_W = \langle \mathbf{x}, T^*\mathbf{y} \rangle_V.$$

标准正交坐标下， $\langle \mathbf{A}\mathbf{x}, \mathbf{y} \rangle = \mathbf{x}^* \mathbf{A}^* \mathbf{y}$ ，所以伴随矩阵就是共轭转置 (conjugate transpose) $\mathbf{A}^*$ ，实数时是转置 (transpose) $\mathbf{A}^\top$ 。逐元素有 $(\mathbf{A}^\top)_{i,j} = a_{j,i}$ 。复数内积使用共轭，搬回配对时必须使用共轭转置；若把内积误写成 $\mathbf{x}^\top \mathbf{x}$ ，所得数值甚至可能不是非负实数。若输入、输出内积由正定 $\mathbf{M}_V, \mathbf{M}_W$ 表示，伴随矩阵 $\mathbf{B}$ 应满足

$$\mathbf{x}^* \mathbf{A}^* \mathbf{M}_W \mathbf{y} = \mathbf{x}^* \mathbf{M}_V \mathbf{B} \mathbf{y}, \quad \text{即} \quad \mathbf{M}_V \mathbf{B} = \mathbf{A}^* \mathbf{M}_W.$$

逆矩阵建立后再求出 $\mathbf{B}$ 的显式形式。伴随完成的是配对转移，不是一般意义的逆：例如 $\mathbf{A} = 2\mathbf{I}$ 的伴随仍为 $2\mathbf{I}$ ，反向恢复输入却应除以 2。

一个变换可能在某方向拉伸、在另一方向压缩。除了逐方向的长度变化，还可以问：由一组向量围出的体积被放大了多少，是否被压成更低维的形状？对方阵，行列式回答这个问题。行列式 (determinant) 由对每列线性、交换两列变号和 $\det \mathbf{I} = 1$ 刻画；实数域中 $|\det \mathbf{A}|$ 给出体积的缩放比例，符号则区分是否改变空间的定向，例如平面上的一次镜像会使符号变负。列相关时平行多面体被压低维，行列式为零。例如取 $\mathbf{X}_\epsilon$ 前两行得

到 $\mathbf{A}_\varepsilon = \begin{bmatrix} 1 & 1 \\ 1 & 1+\varepsilon \end{bmatrix}$, 则 $\det \mathbf{A}_\varepsilon = \varepsilon$ 。复合满足 $\det(\mathbf{AB}) = \det \mathbf{A} \det \mathbf{B}$ 。行列式检测体积退化, 却随整体尺度和维数变化, 不能独自衡量某个方向的误差放大。

6.2.2 线性变换的组合

组合需要先问: 是把同一输入的多输出叠加, 还是把一个输出接到另一个输入? 这分别对应矩阵加法与矩阵乘法。数组形状和索引能帮助检查它们, 但不能替代定义域、陪域及运算次序的检查。

6.2.2.1 线性变换的叠加

若 $T, S : V \rightarrow W$, 定义 $(aT + bS)\mathbf{x} = aT\mathbf{x} + bS\mathbf{x}$; 在相同的两端基下其矩阵为 $a\mathbf{A} + b\mathbf{B}$ 。输入或输出空间不同时, 不能直接将两个映射相加。固定一个数值掩码 $\mathbf{M}$ 后, $\mathbf{X} \mapsto \mathbf{M} \odot \mathbf{X}$ 也是数组空间上的线性映射, 其中逐元素乘积 (Hadamard product) 满足 $(\mathbf{M} \odot \mathbf{X})_{i,j} = m_{i,j}x_{i,j}$, 不对索引求和。例如

$$\begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix} \odot \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix} = \begin{bmatrix} 0 & 2 \\ 3 & 0 \end{bmatrix},$$

相同两矩阵的普通乘积却是 $\begin{bmatrix} 2 & 1 \\ 4 & 3 \end{bmatrix}$ 。掩码依赖所选坐标; 若两个因子都作为未知量, 乘积是分别线性而非联合线性, 因为同时将两者放大两倍会把结果放大四倍。

6.2.2.2 线性变换的复合

若 $T : U \rightarrow V$ 、 $S : V \rightarrow W$, 复合 $S \circ T$ 在相容基下表示为 $[\mathbf{S}][\mathbf{T}]$ 。对 $\mathbf{A} \in \mathbb{F}^{m \times d}$ 、 $\mathbf{B} \in \mathbb{F}^{d \times k}$,

$$(\mathbf{AB})_{i,j} = \sum_{\ell=1}^d a_{i,\ell} b_{\ell,j}, \quad \mathbf{AB} \in \mathbb{F}^{m \times k}. \quad (6.15)$$

被消去的中间索引对应中间空间。先交换坐标再保留第一坐标, 与先保留第一坐标再交换, 结果不同:

$$\begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix} = \begin{bmatrix} 0 & 1 \\ 0 & 0 \end{bmatrix}, \quad \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix} \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix} = \begin{bmatrix} 0 & 0 \\ 1 & 0 \end{bmatrix}.$$

一般不能交换因子。配对反向传递还给出 $(\mathbf{AB})^* = \mathbf{B}^* \mathbf{A}^*$ 。

按输入和输出的分组分块, 同一规则成为 $\mathbf{C}_{i,j} = \sum_{\ell} \mathbf{A}_{i,\ell} \mathbf{B}_{\ell,j}$; 只有对应块尺寸相容时才可以这样计算。更一般的张量缩并 (tensor contraction) 将指定索引对齐相乘再求和。例如 $\mathbf{A} \in \mathbb{R}^{m \times d \times r}$ 、 $\mathbf{B} \in \mathbb{R}^{d \times n \times r}$ 可定义 $c_{i,j} = \sum_{k=1}^d \sum_{s=1}^r a_{i,k,s} b_{k,j,s}$ 。对 $\mathbf{X} \in \mathbb{R}^{b \times \ell \times d}$ 的最后一轴应用同一矩阵

$W \in \mathbb{R}^{d \times h}$, 则 $z_{i,j,r} = \sum_k x_{i,j,k} w_{k,r}$, 输出形状为 $b \times \ell \times h$ 。写出索引能检查哪些轴被消去、哪些轴应当保留。

方阵的迹 (trace) 为 $\text{tr} \mathbf{A} = \sum_i a_{i,i}$, 是将两个索引对齐后求和。对 $\mathbf{A} \in \mathbb{F}^{m \times n}$ 、 $\mathbf{B} \in \mathbb{F}^{n \times m}$,

$$\text{tr}(\mathbf{AB}) = \sum_{i,j} a_{i,j} b_{j,i} = \text{tr}(\mathbf{BA}). \quad (6.16)$$

更多因子只能合法循环移动, 一般不能任意换序。因此 $\text{tr}(\mathbf{ABC}) = \text{tr}(\mathbf{BCA})$, 但不保证等于 $\text{tr}(\mathbf{ACB})$ 。相似变换不改变迹。Frobenius 内积也可写成 $\text{tr}(\mathbf{A}^* \mathbf{B})$ 。

若一个变换作用于数组的第一组索引, 另一个变换作用于第二组索引, 把两者合成一个大矩阵时, 需要同时保留两组输入和输出索引。Kronecker 积 (Kronecker product) 正是这种成对记录:

$$\mathbf{A} \otimes \mathbf{B} = \begin{bmatrix} a_{1,1} \mathbf{B} & \cdots & a_{1,n} \mathbf{B} \\ \vdots & \ddots & \vdots \\ a_{m,1} \mathbf{B} & \cdots & a_{m,n} \mathbf{B} \end{bmatrix} \in \mathbb{F}^{mp \times nq}, \quad \mathbf{A} \in \mathbb{F}^{m \times n}, \mathbf{B} \in \mathbb{F}^{p \times q}. \quad (6.17)$$

按成对索引分别求和可得相容乘积的混合规则

$$(\mathbf{A} \otimes \mathbf{B})(\mathbf{C} \otimes \mathbf{D}) = (\mathbf{AC}) \otimes (\mathbf{BD}). \quad (6.18)$$

对 $\mathbf{A} \in \mathbb{F}^{p \times m}$ 、 $\mathbf{X} \in \mathbb{F}^{m \times n}$ 、 $\mathbf{B} \in \mathbb{F}^{n \times q}$, 按列向量化给出

$$\text{vec}(\mathbf{AXB}) = (\mathbf{B}^\top \otimes \mathbf{A}) \text{vec}(\mathbf{X}). \quad (6.19)$$

证明只需看输出索引 $i + (j-1)p$: 两侧该元素均为 $\sum_{\ell=1}^m \sum_{k=1}^n a_{i,\ell} x_{\ell,k} b_{k,j}$ 。这里是普通转置而非共轭转置, 即使在复数域中也如此, 因为元素乘法没有共轭。固定 $\mathbf{A}, \mathbf{B}$ 后这是关于 $\mathbf{X}$ 的线性映射, 不是关于全部因子的联合线性映射。实际执行左右乘法往往比构造巨大的 Kronecker 矩阵省存储。

运算	形状条件与输出	索引作用
$\mathbf{AB}$	$(m \times n)(n \times p) \rightarrow m \times p$	汇总共同索引
$\mathbf{A} \odot \mathbf{B}$	同为 $m \times n$, 输出仍为 $m \times n$	同位置相乘, 不求和
$\mathbf{A} \otimes \mathbf{B}$	$(m \times n)$ 与 $(p \times q) \rightarrow (mp) \times (nq)$	保留两组成对索引
$\mathbf{x}^* \mathbf{y}$	两个 n 维向量, 输出标量	共轭配对后汇总

表 6.1 相乘符号对应不同操作。先检查消去哪些索引, 再判断其线性性和输出含义。

从多个位置读取内容时, 可以先比较当前需求与各位置的特征, 再按匹配程度加权汇总内容。这类计算需要区分用于比较的特征与真正读取的内容, 也能展示哪些索引在相乘后被消去。设 ℓ 个位置的查询、键和值分别

为 $\mathbf{Q}, \mathbf{K} \in \mathbb{R}^{\ell \times d_k}$ 、 $\mathbf{V} \in \mathbb{R}^{\ell \times d_v}$ 。查询描述要匹配的特征，键用于打分，值是实际读取的内容。注意力（attention）的一种计算为

$$\mathbf{S} = \frac{\mathbf{Q}\mathbf{K}^\top}{\sqrt{d_k}} \in \mathbb{R}^{\ell \times \ell}, \quad (6.20)$$

$$a_{i,j} = \frac{\exp(s_{i,j})}{\sum_{r=1}^{\ell} \exp(s_{i,r})}, \quad \mathbf{O} = \mathbf{A}\mathbf{V} \in \mathbb{R}^{\ell \times d_v}. \quad (6.21)$$

第一次缩并消去特征轴，第二次消去被读取的位置轴。非负且每行和为 1 说明这是加权平均；概率解释还需另有随机对象。固定 $\mathbf{A}$ 时对 $\mathbf{V}$ 线性，但 $\mathbf{Q}, \mathbf{K}, \mathbf{V}$ 通常依赖同一输入，完整注意力并不因此线性。

查询数也不必等于键数。例如

$$\mathbf{Q} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}, \quad \mathbf{K} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 1 & 1 \end{bmatrix}, \quad \mathbf{V} = (v_1, v_2, v_3)^\top.$$

两个查询与三个键的配对给出

$$\mathbf{Q}\mathbf{K}^\top = \begin{bmatrix} 1 & 0 & 1 \\ 0 & 1 & 1 \end{bmatrix}.$$

权重形状为 2×3 ，输出为 2×1 ；需要匹配的是特征轴，不是位置数。再取 $\mathbf{Q} = \mathbf{K} = \mathbf{I}_2$ 和 $\mathbf{V} = \begin{bmatrix} 1 & 1 \\ 1 & 1+\varepsilon \end{bmatrix}$ ，记 $c = \exp(1/\sqrt{2})$ ，则

$$\mathbf{A} = \frac{1}{c+1} \begin{bmatrix} c & 1 \\ 1 & c \end{bmatrix}, \quad \mathbf{O} = \begin{bmatrix} 1 & 1 + \varepsilon/(c+1) \\ 1 & 1 + c\varepsilon/(c+1) \end{bmatrix}.$$

两列之差为 $\varepsilon(1, c)^\top/(c+1)$ ，仍是 $O(|\varepsilon|)$ ；另一方面每个输出行是 $\mathbf{V}$ 各行的加权平均，属于它们的张成空间。前一个计算比较两项输出特征是否仍然接近，后一个计算说明每个位置的输出来自哪些输入位置。二者分别沿特征轴和位置轴讨论，不能把列之间的关系当成行之间的关系。

卷积（convolution）则读取局部位置并复用固定核。对窗口 $\mathbf{U} \in \mathbb{R}^{k_h \times k_w \times c_{in}}$ 和核 $\mathbf{K} \in \mathbb{R}^{k_h \times k_w \times c_{in} \times c_{out}}$ ，忽略偏置时

$$z_r = \sum_{a=1}^{k_h} \sum_{b=1}^{k_w} \sum_{s=1}^{c_{in}} u_{a,b,s} k_{a,b,s,r}. \quad (6.22)$$

固定核后它对窗口线性；窗口移动时复用核，但边界、步幅及核是否翻转必须另外规定。此处的同向索引写法是模型中常称为卷积的互相关形式。取一维双通道窗口 $\mathbf{U} = \begin{bmatrix} 1 & 1 \\ 1 & 1+\varepsilon \end{bmatrix}$ ，这里每行表示一个位置，每列表示一个通道。取第一列为 $(1/2, 1/2)^\top$ 、第二列为零的核 $\mathbf{K}_1$ ，输出为两个位置第一通道的平均值 1；取 $\mathbf{K}_2 = \begin{bmatrix} 0 & -1 \\ 0 & 1 \end{bmatrix}$ ，输出为第二通道在两个位置的差值 ε 。

两个核分别保留共同水平与局部差异。这样写出索引，可以核对模型实际读取了什么；这些读取是否适合当前任务，还需要另作判断。

6.2.3 线性变换的比较

行列式比较体积，迹汇总对角，但它们都不回答“某个输入误差最多被放大多少”。为此必须同时指定输入和输出的范数。在矩阵空间上满足范数公理的函数称为矩阵范数（matrix norm）。下面用最大输入放大率构造其中一类。

定义 6.8 由向量范数诱导的矩阵范数 给定输入范数 $\|\cdot\|_\alpha$ 和输出范数 $\|\cdot\|_\beta$ ，诱导矩阵范数（induced matrix norm）为

$$\|A\|_{\alpha \rightarrow \beta} = \max_{x \neq 0} \frac{\|Ax\|_\beta}{\|x\|_\alpha}.$$

两端采用同一类 p 范数时简写为 $\|A\|_p$ 。

有限维单位球紧保证最大值存在。直接由定义， $\|Ax\|_\beta \leq \|A\|_{\alpha \rightarrow \beta} \|x\|_\alpha$ ；对两个变换则有 $\|(A-B)x\|_\beta \leq \|A-B\|_{\alpha \rightarrow \beta} \|x\|_\alpha$ 。若中间空间的范数匹配，连续应用两次界得到次乘性

$$\|AB\|_{\alpha \rightarrow \gamma} \leq \|A\|_{\beta \rightarrow \gamma} \|B\|_{\alpha \rightarrow \beta}.$$

对于标准坐标，两个诱导范数可直接读取：

$$\|A\|_1 = \max_j \sum_i |a_{i,j}|, \quad \|A\|_\infty = \max_i \sum_j |a_{i,j}|.$$

第一式的上界由三角不等式得到，在最大绝对列和对应的坐标向量上达到；第二式在最大绝对行和对应的一行中，取输入各坐标相位使该行各项同相，即达到。诱导 2 范数也称谱范数（spectral norm），此处先写为

$$\|A\|_2 = \max_{\|x\|_2=1} \|Ax\|_2.$$

它的奇异值表达在第 6.5 节推导。

Frobenius 范数从另一个角度累计作用：

$$\|A\|_F^2 = \sum_j \|Ae_j\|_2^2 = \sum_{i,j} |a_{i,j}|^2.$$

它是所有标准输入方向的总平方输出，而非一次最坏输入。对 $\mathbf{A} = \begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix}$, $\|\mathbf{A}\|_1 = \|\mathbf{A}\|_\infty = 2$, $\|\mathbf{A}\|_F = \sqrt{3}$, 各数值不必相同。逐列应用诱导范数界, 再对伴随应用同样结论, 得到

$$\|\mathbf{AB}\|_F \leq \|\mathbf{A}\|_2 \|\mathbf{B}\|_F, \quad \|\mathbf{AB}\|_F \leq \|\mathbf{A}\|_F \|\mathbf{B}\|_2. \quad (6.23)$$

其中 $\|\mathbf{B}^*\|_2 = \|\mathbf{B}\|_2$ 可由 $\|\mathbf{B}\|_2 = \max_{\|\mathbf{x}\|_2=\|\mathbf{y}\|_2=1} |\mathbf{y}^* \mathbf{B} \mathbf{x}|$ 交换两向量得到, 不需预先使用 SVD。又因 $\|\mathbf{A}\|_2 \leq \|\mathbf{A}\|_F$, Frobenius 范数也次乘。

分组误差需要再固定分组方式。例如以行为组,

$$\|\mathbf{A}\|_{p,q} = \left(\sum_i \|\mathbf{A}_{i,:}\|_p^q \right)^{1/q}, \quad 1 \leq p, q < \infty, \quad \|\mathbf{A}\|_{p,\infty} = \max_i \|\mathbf{A}_{i,:}\|_p.$$

内层范数衡量每组中的元素, 外层范数汇总各组的大小; $p = \infty$ 时, 内层取组内最大绝对值。例如 $\|\mathbf{A}\|_{2,1}$ 对每行先求欧氏长度再相加; 把它加入优化目标作为惩罚, 可以鼓励整行同时为零, 而不只是让分散的单个元素变小。这里明确以行为组, 其他文献可能交换下标约定。这类混合范数 (mixed norm) 不是自动诱导的算子范数, 不能不查维数与定义便套用次乘性, 也不只由奇异值决定。

换基时, 保持同一抽象几何需同时变换范数。若新坐标 $\mathbf{z} = \mathbf{S} \mathbf{x}$, 原长度应写成 $\|\mathbf{S}^{-1} \mathbf{z}\|$ 。把新坐标直接按普通欧氏长度比较, 一般已经换了问题。复方阵 $\mathbf{U}$ 满足 $\mathbf{U}^* \mathbf{U} = \mathbf{I}$ 时, 称为酉矩阵 (unitary matrix)。它保持长度, 因为

$$\|\mathbf{U} \mathbf{x}\|_2^2 = \mathbf{x}^* \mathbf{U}^* \mathbf{U} \mathbf{x} = \|\mathbf{x}\|_2^2.$$

实数情形就是正交矩阵。因此两端正交或酉换基保持欧氏几何, 而一般换基不保持。这也是前面的大坐标不能单独解释为大对象的原因。

6.2.4 线性变换的函数运算

固定一个方阵 $\mathbf{A}$ 以后, 可以反复复合它, 并叠加不同次数的作用。这定义矩阵多项式 $p(\mathbf{A}) = \sum_{j=0}^k a_j \mathbf{A}^j$, 其中 $\mathbf{A}^0 = \mathbf{I}$ 。矩形矩阵一般不能同自身复合, 故此处要求方阵。与逐元素函数也要区分: 若 $\mathbf{N} = \begin{bmatrix} 0 & 1 \\ 0 & 0 \end{bmatrix}$, 则 $\mathbf{N}^2 = \mathbf{0}$, 矩阵指数为 $\mathbf{I} + \mathbf{N}$, 并不是将四个元素分别取指数所得的数表。

标量幂级数 $f(z) = \sum_{j=0}^{\infty} a_j z^j$ 在收敛半径 R 内绝对收敛。使用同一向量范数诱导的矩阵范数时, 若 $\|\mathbf{A}\| < R$, 则

$$\sum_{j=0}^{\infty} \|a_j \mathbf{A}^j\| \leq \sum_{j=0}^{\infty} |a_j| \|\mathbf{A}\|^j < \infty.$$

有限维矩阵空间完备, 所以级数收敛, 并可定义 $f(\mathbf{A})$ 。这是便于检验的充分条件, 不是必要条件; 第 6.4.1 节将以谱半径给出更细结论。特别地,

$$\exp(\mathbf{A}) = e^{\mathbf{A}} = \sum_{j=0}^{\infty} \frac{\mathbf{A}^j}{j!} \quad (6.24)$$

对任意有限方阵都收敛, 且 $\|e^{\mathbf{A}}\| \leq e^{\|\mathbf{A}\|}$ 。用前 $k+1$ 项计算时, 尾项范数不超过 $e^{\|\mathbf{A}\|} \|\mathbf{A}\|^{k+1}/(k+1)!$ 。这控制截断误差, 尚不评价浮点求和的误差。

标量恒等式不能忽略非交换性。按 t 展开,

$$e^{t\mathbf{A}}e^{t\mathbf{B}} - e^{t(\mathbf{A}+\mathbf{B})} = \frac{t^2}{2}(\mathbf{AB} - \mathbf{BA}) + O(t^3).$$

所以一般 $e^{\mathbf{A}+\mathbf{B}} \neq e^{\mathbf{A}}e^{\mathbf{B}}$; 若 $\mathbf{AB} = \mathbf{BA}$, 绝对收敛允许重排级数, 二项式公式才恢复这个等式。同理 $\sum_{j \geq 0} \mathbf{A}^j$ 在 $\|\mathbf{A}\| < 1$ 时收敛, 其部分和乘 $\mathbf{I} - \mathbf{A}$ 得到 $\mathbf{I} - \mathbf{A}^{k+1}$, 为后面构造逆提供依据。平方根、对数和实数次幂则必须检查谱及定义域, 不能仅凭逐元素公式定义。

6.3 线性变换的逆与方程求解

正向作用给定输入求输出, 反向问题则固定矩阵和目标, 寻找输入:

$$\mathbf{Ax} = \mathbf{b}, \quad \mathbf{A} \in \mathbb{F}^{m \times d}, \quad \mathbf{x} \in \mathbb{F}^d, \quad \mathbf{b} \in \mathbb{F}^m. \quad (6.25)$$

目标未必可达, 输入也未必唯一, 所以“求解”之前必须规定: 要求精确达到目标, 还是使残差最小; 若多个输入都达到同样结果, 再依据什么选择? 本节默认两端为标准欧氏或复内积, 改权重时明确说明。

未知量也可以是矩阵。例如 $\mathbf{AZB} = \mathbf{C}$ 固定 $\mathbf{A}, \mathbf{B}$ 后对 $\mathbf{Z}$ 线性, 式 (6.19) 将其编码为普通向量方程。也可能要求同一个未知矩阵在左、右两次线性作用下的结果之和达到给定目标。这种问题依然对未知矩阵线性, 下面用 Sylvester 方程统一表示。

定义 6.9 Sylvester 方程 给定 $\mathbf{A} \in \mathbb{F}^{m \times m}$ 、 $\mathbf{B} \in \mathbb{F}^{n \times n}$ 和 $\mathbf{C} \in \mathbb{F}^{m \times n}$, 关于 $\mathbf{Z} \in \mathbb{F}^{m \times n}$ 的方程

$$\mathbf{AZ} + \mathbf{ZB} = \mathbf{C}$$

称为 Sylvester 方程 (Sylvester equation)。

它的向量化形式为 $[\mathbf{I}_n \otimes \mathbf{A} + \mathbf{B}^T \otimes \mathbf{I}_m] \text{vec}(\mathbf{Z}) = \text{vec}(\mathbf{C})$ 。这让向量系统的求解方法可以直接使用, 也说明矩阵未知量依然属于一个线性空间; 大规模时应利用左右乘法避免存储 $mn \times mn$ 矩阵。例如对角 $\mathbf{A} = \text{diag}(1, 2)$ 、 $\mathbf{B} = \text{diag}(3, 4)$ 时, $z_{i,j} = c_{i,j}/(a_{i,i} + b_{j,j})$ 。若某个和为零, 对应右端非零则无解, 为零则留下自由度。一般矩阵的谱条件将在第 6.4.1.2 小节建立。

6.3.1 方程解的存在与选择

输出可达与不可达决定精确求解还是最小残差；输入不唯一却可能出现在这两种情形中。因此最小范数不是与前两者互斥的第三类方程，而是在确定拟合目标后附加的选解规则。

6.3.1.1 输出可达时的精确解

若要判断 $\mathbf{b}$ 能否由某个输入产生，可以先收集 $\mathbf{A}$ 的所有可能输出；若要判断输入是否唯一，则找出哪些输入方向被它完全消去。这分别对应列空间与零空间。列空间（column space） $\text{col}(\mathbf{A}) = \text{range}(\mathbf{A}) = \{\mathbf{Ax} : \mathbf{x} \in \mathbb{F}^d\}$ 记录可达输出；零空间（null space） $\text{null}(\mathbf{A}) = \{\mathbf{x} : \mathbf{Ax} = \mathbf{0}\}$ 记录被消去的输入。每一行都从输入中读取一个线性组合，把这些读取方向张成的空间称为行空间（row space） $\text{range}(\mathbf{A}^*) \subseteq \mathbb{F}^d$ 。实数时，把各行转成列即可得到这些方向；复数内积使用共轭，所以还要对各行取共轭。左零空间 $\text{null}(\mathbf{A}^*) \subseteq \mathbb{F}^m$ 则记录与全部可达输出正交的方向：沿这些方向读取，所有 $\mathbf{Ax}$ 都给出零。由配对等式，

$$\text{null}(\mathbf{A}) = \text{range}(\mathbf{A}^*)^\perp, \quad \text{null}(\mathbf{A}^*) = \text{range}(\mathbf{A})^\perp.$$

例如 $\mathbf{x}$ 与 $\mathbf{A}^*\mathbf{y}$ 对所有 $\mathbf{y}$ 正交，当且仅当 $\mathbf{y}^*\mathbf{Ax} = 0$ 对所有 $\mathbf{y}$ 成立，也就是 $\mathbf{Ax} = \mathbf{0}$ 。这同时解释了四个子空间分属输入端与输出端。

秩（rank）是值域维数，零度是零空间维数。

定理 6.10 秩零度定理 有限维线性映射 $T : V \rightarrow W$ 满足 $\dim V = \dim \text{null}(T) + \dim \text{range}(T)$ 。因此对 $\mathbf{A} \in \mathbb{F}^{m \times d}$ ， $d = \dim \text{null}(\mathbf{A}) + \text{rank}(\mathbf{A})$ 。

证明. 取零空间的基 $\mathbf{v}_1, \dots, \mathbf{v}_r$ 并扩充成 V 的基 $\mathbf{v}_1, \dots, \mathbf{v}_d$ 。前 r 个基向量的像为零，所以其余的像 $T\mathbf{v}_{r+1}, \dots, T\mathbf{v}_d$ 张成值域。若 $\sum_{j>r} a_j T\mathbf{v}_j = \mathbf{0}$ ，则 $\sum_{j>r} a_j \mathbf{v}_j$ 属于零空间，能由前 r 个基向量表示。整个基的线性无关性迫使全部 $a_j = 0$ ，所以这些像也是无关组。值域维数为 $d - r$ ，结论成立。■

再由正交补关系， $\text{rank}(\mathbf{A}^*) = d - \dim \text{null}(\mathbf{A}) = \text{rank}(\mathbf{A})$ ，证明行秩与列秩相等。若 $\text{rank}(\mathbf{A}) = r$ ，列空间、零空间、行空间和左零空间的维数依次为 $r, d - r, r, m - r$ 。

方程存在精确解称为相容，即 $\mathbf{b} \in \text{range}(\mathbf{A})$ ，等价于 $\mathbf{y}^*\mathbf{b} = 0$ 对所有 $\mathbf{y} \in \text{null}(\mathbf{A}^*)$ 成立。若 $\mathbf{x}_0$ 为特解，全部解恰为 $\mathbf{x}_0 + \text{null}(\mathbf{A})$ ：加上零空间向量不改输出，而两解之差必被 $\mathbf{A}$ 消去。因此，已有解时，解唯一当且仅当零空间只含零向量。单看方程数和未知数个数不能判断相容性；欠定且相容时才必然存在非零自由度。

商空间把这种不可区分性表达为精确对应：

$$\mathbb{F}^d / \text{null}(\mathbf{A}) \longrightarrow \text{range}(\mathbf{A}), \quad \mathbf{x} + \text{null}(\mathbf{A}) \longmapsto \mathbf{A}\mathbf{x}.$$

同一等价类中的输入给出同一输出，所以这个对应不依赖代表元；不同类给出不同输出，而每个可达输出都对应一个类。它因而是线性的双射，但仍没有从每个类中挑出一个具体输入。在 $\mathbf{X}_0$ 下，零空间为 $\text{span}\{(1, -1)^\top\}$ ； $(1, 0)^\top$ 和 $(0, 1)^\top$ 属于同一类，都输出 $\mathbf{c}_1$ 。这一类只记录系数和，不记录两列分别承担多少。

方阵 $\mathbf{A} \in \mathbb{F}^{d \times d}$ 若单射，秩零度给出满射，反之亦然。每个右端的唯一解于是定义线性逆映射，其矩阵 $\mathbf{A}^{-1}$ 满足 $\mathbf{A}^{-1}\mathbf{A} = \mathbf{A}\mathbf{A}^{-1} = \mathbf{I}$ 。两个候选逆相乘可立即证明唯一性。以下条件等价：列无关、列张成全空间、秩为 d 、 $\det \mathbf{A} \neq 0$ 以及存在双侧逆。可逆时 $\det(\mathbf{A}^{-1}) = 1/\det \mathbf{A}$ ，相容乘积的逆为 $(\mathbf{A}\mathbf{B})^{-1} = \mathbf{B}^{-1}\mathbf{A}^{-1}$ 。

矩形矩阵没有这样的双侧逆。满列秩时 $\mathbf{A}^*\mathbf{A}$ 正定，故 $\mathbf{L} = (\mathbf{A}^*\mathbf{A})^{-1}\mathbf{A}^*$ 满足 $\mathbf{L}\mathbf{A} = \mathbf{I}$ ，是左逆；满行秩时 $\mathbf{R} = \mathbf{A}^*(\mathbf{A}\mathbf{A}^*)^{-1}$ 满足 $\mathbf{A}\mathbf{R} = \mathbf{I}$ ，是右逆。单侧逆一般不唯一。例如 $(1, 0)^\top$ 有任意左逆 $(1, t)$ ，而行向量 $(1, 0)$ 有任意右逆 $(1, t)^\top$ 。左逆恢复所有输入，但只能在可达输出上反演；右逆给每个输出挑一个输入，不能恢复被零空间消去的信息。

现在可回接加权伴随： $\mathbf{A}^\sharp = \mathbf{M}_V^{-1}\mathbf{A}^*\mathbf{M}_W$ ，其中两端权重均正定。例如 $\mathbf{A} = \begin{bmatrix} 0 & 1 \\ 0 & 0 \end{bmatrix}$ 、 $\mathbf{M}_V = \mathbf{M}_W = \text{diag}(1, 4)$ 时， $\mathbf{A}^\sharp = \begin{bmatrix} 0 & 0 \\ 1/4 & 0 \end{bmatrix}$ ，而普通转置的对应元素为 1。伴随随几何改变，仍不等于逆。同样，式 (6.18) 现在给出 $(\mathbf{A} \otimes \mathbf{B})^{-1} = \mathbf{A}^{-1} \otimes \mathbf{B}^{-1}$ ，前提是两个因子均为可逆方阵。

6.3.1.2 输出不可达时的最小残差解

当 $\mathbf{b}$ 不在值域中，改找离它最近的可达输出，输入端就得到最小二乘 (least squares) 问题。以设计矩阵记号写为

$$\min_{\mathbf{w} \in \mathbb{R}^d} \|\mathbf{X}\mathbf{w} - \mathbf{y}\|_2^2. \quad (6.26)$$

正交投影保证最近的拟合向量 $\hat{\mathbf{y}} = \mathbf{X}\hat{\mathbf{w}}$ 存在且唯一。不过，能产生它的系数 $\hat{\mathbf{w}}$ 可能不唯一，因为多个输入可以到达同一个最近点。残差 $\mathbf{r} = \mathbf{y} - \mathbf{X}\hat{\mathbf{w}}$ 与每一列正交，给出正规方程 (normal equations)

$$\mathbf{X}^\top(\mathbf{y} - \mathbf{X}\hat{\mathbf{w}}) = \mathbf{0}, \quad \mathbf{X}^\top\mathbf{X}\hat{\mathbf{w}} = \mathbf{X}^\top\mathbf{y}. \quad (6.27)$$

“正规”来自法向关系，不是归一化。复数情形改用共轭转置。反过来，对任意增量 $\mathbf{h}$,

$$\|\mathbf{X}(\hat{\mathbf{w}} + \mathbf{h}) - \mathbf{y}\|_2^2 = \|\mathbf{r}\|_2^2 - 2\mathbf{h}^\top\mathbf{X}^\top\mathbf{r} + \|\mathbf{X}\mathbf{h}\|_2^2.$$

正规方程使中间项为零，所以它不仅必要，也足以保证全局最小值。

满列秩时 $\mathbf{X}^\top \mathbf{X}$ 正定且可逆，唯一系数为

$$\hat{\mathbf{w}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}. \quad (6.28)$$

否则任意零空间增量不改目标，系数不唯一。精确解是最小残差为零的特殊情形，而不是另一种完全不相关的定义。

加权最小二乘（weighted least squares）用正定 $\mathbf{M}$ 比较残差，目标为 $(\mathbf{X}\mathbf{w} - \mathbf{y})^\top \mathbf{M}(\mathbf{X}\mathbf{w} - \mathbf{y})$ 。残差在 $\mathbf{M}$ 内积下与列空间正交，因而

$$\mathbf{X}^\top \mathbf{M}(\mathbf{y} - \mathbf{X}\hat{\mathbf{w}}) = \mathbf{0}, \quad \mathbf{X}^\top \mathbf{M} \mathbf{X} \hat{\mathbf{w}} = \mathbf{X}^\top \mathbf{M} \mathbf{y}. \quad (6.29)$$

这正是例 6.7 的多列版本。若 $\mathbf{M}$ 仅半正定，它可能忽略非零残差，因此连最优拟合向量唯一性也不能直接沿用。例如 $\mathbf{X} = \mathbf{I}$ 、 $\mathbf{M} = \text{diag}(1, 0)$ 使第二个拟合坐标任意。

对贯穿例，Gram 方程具体为

$$\begin{bmatrix} 3 & 3 \\ 3 & 3 + 2\varepsilon^2 \end{bmatrix} \hat{\mathbf{w}} = \begin{bmatrix} 3 \\ 3 + 2\varepsilon\delta \end{bmatrix}.$$

系数矩阵行列式为 $6\varepsilon^2$ 。当 $\varepsilon \neq 0$,

$$\hat{\mathbf{w}}_\varepsilon = \begin{bmatrix} 1 - \delta/\varepsilon \\ \delta/\varepsilon \end{bmatrix}, \quad \mathbf{X}_\varepsilon \hat{\mathbf{w}}_\varepsilon = \mathbf{y}. \quad (6.30)$$

$\varepsilon = 0.01$ 、 $\delta = 0.1$ 时系数为 $(-9, 10)^\top$ ，残差却为零。在 $\varepsilon = 0$ 处，目标的正交分解已经是 $\mathbf{y} = \mathbf{c}_1 + \delta \mathbf{q}$ ，故最近输出为 $\mathbf{c}_1$ ，残差为 $\delta \mathbf{q}$ ，平方残差为 $2\delta^2$ ；全部系数满足 $w_1 + w_2 = 1$ 。于是随着矩阵趋于极限，精确拟合所需的系数发散，而极限矩阵不再能精确拟合。这不是计算机造成的现象。

6.3.1.3 解不唯一时的最小范数解

找到最近输出后，仍可能有多个输入能产生它。既然零空间分量不改变输出，去掉这部分就能使输入的欧氏范数最小。下面先用正交分解构造这种选择，再定义伪逆。记 $N = \text{null}(\mathbf{A})$ 、 $R = \text{range}(\mathbf{A})$ 。限制映射 $\mathbf{A}|_{N^\perp} : N^\perp \rightarrow R$ 是双射：单射来自 $N \cap N^\perp = \{\mathbf{0}\}$ ；对任意 $\mathbf{Ax}$ ，把 $\mathbf{x}$ 分解为 $\mathbf{x}_\perp + \mathbf{x}_N$ 即可得到同一输出 $\mathbf{Ax}_\perp$ ，所以满射。这给出不依赖奇异值分解的构造。

定义 6.11 Moore-Penrose 伪逆 在两端标准内积下, Moore-Penrose 伪逆 (Moore-Penrose pseudoinverse) 是线性映射

$$\mathbf{A}^\dagger = (\mathbf{A}|_{N^\perp})^{-1}\mathbf{P}_R : \mathbb{F}^m \longrightarrow \mathbb{F}^d.$$

它先把输出投影到值域, 再在零空间的正交补中反求输入。\$\mathbf{A} = \mathbf{0}\$ 时定义 \$\mathbf{A}^\dagger = \mathbf{0}\$。

普通逆是它在可逆方阵上的特殊情形。满足 \$\mathbf{AGA} = \mathbf{A}\$ 的矩阵常统称广义逆, 它们一般不唯一; 伪逆则通过正交性选定其中唯一的一种。

由构造直接得到 \$\mathbf{AA}^\dagger = \mathbf{P}_R\$、\$\mathbf{A}^\dagger\mathbf{A} = \mathbf{P}_{N^\perp}\$, 所以满足四个 Penrose 条件

$$\begin{aligned}\mathbf{AA}^\dagger\mathbf{A} &= \mathbf{A}, & \mathbf{A}^\dagger\mathbf{AA}^\dagger &= \mathbf{A}^\dagger, \\ (\mathbf{AA}^\dagger)^* &= \mathbf{AA}^\dagger, & (\mathbf{A}^\dagger\mathbf{A})^* &= \mathbf{A}^\dagger\mathbf{A}.\end{aligned}$$

第一项要求先作用 \$\mathbf{A}\$、再用伪逆返回、再作用 \$\mathbf{A}\$, 得到的输出仍是原输出; 第二项对伪逆的作用提出相应要求。后两项使 \$\mathbf{AA}^\dagger\$ 与 \$\mathbf{A}^\dagger\mathbf{A}\$ 成为正交投影。接下来证明: 仅凭这四个条件, 也能唯一确定刚才构造出的伪逆。

设 \$\mathbf{G}\$ 满足四个条件。\$\mathbf{AG}\$ 自伴且幂等, 值域包含于 \$R\$, 并在每个 \$\mathbf{Ax}\$ 上为恒等, 故 \$\mathbf{AG} = \mathbf{P}_R\$。类似地 \$\mathbf{GA}\$ 自伴幂等; 由 \$\mathbf{AGA} = \mathbf{A}\$ 可知 \$\text{null}(\mathbf{GA}) = \text{null}(\mathbf{A})\$, 所以 \$\mathbf{GA} = \mathbf{P}_{N^\perp}\$。于是

$$\mathbf{G} = \mathbf{GAG} = \mathbf{GP}_R = \mathbf{GAA}^\dagger = \mathbf{P}_{N^\perp}\mathbf{A}^\dagger = \mathbf{A}^\dagger.$$

存在性与唯一性至此都已建立, 不需预先引入 SVD。

定理 6.12 最小二乘与最小范数 给定 \$\mathbf{A} \in \mathbb{F}^{m \times d}\$ 和 \$\mathbf{b} \in \mathbb{F}^m\$, 全部最小二乘解为 \$\mathbf{A}^\dagger\mathbf{b} + \text{null}(\mathbf{A})\$。其中 \$\mathbf{x}^\dagger = \mathbf{A}^\dagger\mathbf{b}\$ 是唯一的最小欧氏范数解。若方程相容, 它就是全部精确解中的最小范数者。

证明. 将 \$\mathbf{b} = \mathbf{P}_R\mathbf{b} + \mathbf{b}_\perp\$, \$\mathbf{x} = \mathbf{x}_\perp + \mathbf{x}_N\$ 按两端正交分解, 则

$$\|\mathbf{Ax} - \mathbf{b}\|_2^2 = \|\mathbf{Ax}_\perp - \mathbf{P}_R\mathbf{b}\|_2^2 + \|\mathbf{b}_\perp\|_2^2.$$

第二项不能由输入改变; 第一项在且仅在 \$\mathbf{x}_\perp = (\mathbf{A}|_{N^\perp})^{-1}\mathbf{P}_R\mathbf{b} = \mathbf{A}^\dagger\mathbf{b}\$ 时为零。所以全部最优输入为 \$\mathbf{A}^\dagger\mathbf{b} + \mathbf{x}_N\$。两项正交, 得到 \$\|\mathbf{x}\|_2^2 = \|\mathbf{A}^\dagger\mathbf{b}\|_2^2 + \|\mathbf{x}_N\|_2^2\$, 最小值仅在 \$\mathbf{x}_N = \mathbf{0}\$ 时达到。相容时 \$\mathbf{b}_\perp = \mathbf{0}\$, 同一证明适用。■

例如 \$\mathbf{A} = \begin{bmatrix} 1 & 1 \\ 0 & 0 \end{bmatrix}\$、\$\mathbf{b} = (2, 1)^\top\$, 最近输出是 \$(2, 0)^\top\$, 残差 \$(0, 1)^\top\$ 不可消除。全部最小二乘输入为 \$(1+t, 1-t)^\top\$, 平方范数为 \$2+2t^2\$, 伪逆选择 \$(1, 1)^\top\$。图 6.4 将两次选择画在不同空间; 伪逆没有使原本无解的方程突然可解。




图 6.4 伪逆的两次选择。右图先在可达输出中选择离 $\mathbf{b} = (2, 1)^T$ 最近的 $(2, 0)^T$ ；左图再在整条原像直线 $x_1 + x_2 = 2$ 上选择最靠近原点的 $(1, 1)^T$ 。两图属于不同空间，各自等比例绘制。

满列秩时，正规方程的唯一解给出 $\mathbf{A}^\dagger = (\mathbf{A}^* \mathbf{A})^{-1} \mathbf{A}^*$ ；满行秩时， $\mathbf{A}^* (\mathbf{A} \mathbf{A}^*)^{-1} \mathbf{b}$ 既达到 $\mathbf{b}$ 又属于 $N^\perp$ ，故 $\mathbf{A}^\dagger = \mathbf{A}^* (\mathbf{A} \mathbf{A}^*)^{-1}$ 。这些是推导公式，不是形成逆矩阵的数值建议。一般加权问题若同时改变输出残差和输入范数，投影与正交补也要相应改变，不能直接沿用标准伪逆。伪逆虽对每个固定矩阵唯一，却不保证随矩阵连续，例如非零标量 ε 的伪逆为 $1/\varepsilon$ ，而零标量的伪逆为零；秩改变是必须检查的边界。

6.3.2 基于分解与消元的直接求解

目标确定后，需要把方程改写成容易求解的形式。直接法通常先花主要成本分解矩阵，随后处理右端；同一矩阵有多个右端时可以复用分解。下面两条路线分别利用消元和保持欧氏长度的正交变换，最终都归结为三角系统。这里先讲精确运算，舍入与可靠性在第 6.6.2 小节统一评价。

6.3.2.1 消元与三角求解

高斯消元用一行的倍数消去另一行的某个系数。例如 $\begin{bmatrix} 2 & 1 \\ 4 & 3 \end{bmatrix} \mathbf{x} = (1, 3)^T$ ，第二行减第一行的两倍得到 $x_2 = 1$ ，再代回得 $x_1 = 0$ 。一般非奇异方阵使用带部分主元的 LU 分解

$$\mathbf{P}\mathbf{A} = \mathbf{L}\mathbf{U}, \quad (6.31)$$

其中 $\mathbf{P}$ 记录行交换， $\mathbf{L}$ 单位下三角， $\mathbf{U}$ 上三角。第 k 步在尚未处理的第 k 列中选择绝对值最大的元素移到主元位置，再用 $l_{i,k} = a_{i,k}^{(k)} / a_{k,k}^{(k)}$ 消去下面的元素。前面列的乘子也要随行交换同步更新。主元选择避免把本可交换

避开的零元素拿来作除数，不会把奇异矩阵变可逆；精确算术出现无可用主元时需报告秩亏或转入适当的秩揭示方法。

求解分成 $\mathbf{Lz} = \mathbf{Pb}$ 的前代和 $\mathbf{Ux} = \mathbf{z}$ 的回代：

$$z_i = (\mathbf{Pb})_i - \sum_{j < i} l_{i,j} z_j, \quad x_i = \frac{z_i - \sum_{j > i} u_{i,j} x_j}{u_{i,i}}.$$

稠密 $d \times d$ 矩阵分解约需 $2d^3/3$ 次基本浮点运算，存储 $O(d^2)$ ，每个新右端的两次三角求解为 $O(d^2)$ 。稀疏矩阵消元可能产生原来没有的非零元，称为填充，因此存储收益还取决于排序与结构，而不只看原始非零元数。

正定结构能减少工作。若 $\mathbf{A} = \mathbf{A}^T > 0$ ，则存在唯一的对角元为正的下三角矩阵 $\mathbf{L}$ 使

$$\mathbf{A} = \mathbf{L}\mathbf{L}^T. \quad (6.32)$$

这称为Cholesky分解（Cholesky decomposition）。它可逐列计算

$$l_{j,j} = \sqrt{a_{j,j} - \sum_{k < j} l_{j,k}^2}, \quad l_{i,j} = \frac{a_{i,j} - \sum_{k < j} l_{i,k} l_{j,k}}{l_{j,j}} \quad (i > j).$$

正定性保证每步剩余二次型仍正定，因而根号内严格为正；每列由先前列唯一确定，也证明带正对角的分解唯一。复 Hermitian 情形把转置改为共轭转置，平方改为模方，交叉乘积 $l_{i,k} l_{j,k}$ 中的第二因子取共轭。求解依次用 $\mathbf{Lz} = \mathbf{b}$ 与 $\mathbf{L}^* \mathbf{x} = \mathbf{z}$ 。稠密矩阵的分解约需 $d^3/3$ 次基本浮点运算，只需存储下三角部分。半正定时可能出现零主元，上述除法就不再适用。此时先要区分矩阵确实退化，还是舍入造成了异常；添加对角常数会改变原方程。

按一组变量而非一个变量消元，就得到分块形式。设 $\mathbf{M} = \begin{bmatrix} \mathbf{A} & \mathbf{B} \\ \mathbf{C} & \mathbf{D} \end{bmatrix}$ ，其中 $\mathbf{A} \in \mathbb{F}^{p \times p}$ 可逆， $\mathbf{B} \in \mathbb{F}^{p \times q}$ 、 $\mathbf{C} \in \mathbb{F}^{q \times p}$ 、 $\mathbf{D} \in \mathbb{F}^{q \times q}$ 。把未知量分成两组 $\mathbf{x}$ 与 $\mathbf{y}$ 。先从第一组方程解出 $\mathbf{x}$ ，再代入第二组，就能把两组变量的联合问题缩成只含 $\mathbf{y}$ 的问题。消元后剩下的系数矩阵称为 Schur 补。

定义 6.13 Schur 补 $\mathbf{A}$ 在 $\mathbf{M}$ 中的 Schur 补（Schur complement）为 $\mathbf{S} = \mathbf{D} - \mathbf{C}\mathbf{A}^{-1}\mathbf{B}$ 。

对右端 $(\mathbf{f}^T, \mathbf{g}^T)^T$ ，第一行给出 $\mathbf{x} = \mathbf{A}^{-1}(\mathbf{f} - \mathbf{B}\mathbf{y})$ ，代入第二行得到 $\mathbf{S}\mathbf{y} = \mathbf{g} - \mathbf{C}\mathbf{A}^{-1}\mathbf{f}$ 。矩阵形式即

$$\begin{bmatrix} \mathbf{I} & \mathbf{0} \\ -\mathbf{C}\mathbf{A}^{-1} & \mathbf{I} \end{bmatrix} \begin{bmatrix} \mathbf{A} & \mathbf{B} \\ \mathbf{C} & \mathbf{D} \end{bmatrix} = \begin{bmatrix} \mathbf{A} & \mathbf{B} \\ \mathbf{0} & \mathbf{S} \end{bmatrix}. \quad (6.33)$$

所以 $\det \mathbf{M} = \det \mathbf{A} \det \mathbf{S}$, 并且在 $\mathbf{A}$ 可逆的前提下, $\mathbf{M}$ 可逆当且仅当 $\mathbf{S}$ 可逆。此时逐块解方程得到

$$\mathbf{M}^{-1} = \begin{bmatrix} \mathbf{A}^{-1} + \mathbf{A}^{-1} \mathbf{B} \mathbf{S}^{-1} \mathbf{C} \mathbf{A}^{-1} & -\mathbf{A}^{-1} \mathbf{B} \mathbf{S}^{-1} \\ -\mathbf{S}^{-1} \mathbf{C} \mathbf{A}^{-1} & \mathbf{S}^{-1} \end{bmatrix}. \quad (6.34)$$

这些式子将在条件高斯与状态估计中再次出现; 实际实现通过求解来应用逆, 而不是为了套公式先形成全部逆矩阵。

对称分块 $\mathbf{C} = \mathbf{B}^\top$ 还连接二次型。配方给出

$$\begin{bmatrix} \mathbf{x} \\ \mathbf{y} \end{bmatrix}^\top \mathbf{M} \begin{bmatrix} \mathbf{x} \\ \mathbf{y} \end{bmatrix} = (\mathbf{x} + \mathbf{A}^{-1} \mathbf{B} \mathbf{y})^\top \mathbf{A} (\mathbf{x} + \mathbf{A}^{-1} \mathbf{B} \mathbf{y}) + \mathbf{y}^\top \mathbf{S} \mathbf{y}.$$

因此在 $\mathbf{A} > 0$ 时,

$$\mathbf{M} > 0 \iff \mathbf{D} - \mathbf{B}^\top \mathbf{A}^{-1} \mathbf{B} > 0. \quad (6.35)$$

必要性可取 $\mathbf{x} = -\mathbf{A}^{-1} \mathbf{B} \mathbf{y}$, 充分性来自两项非负且不能同时为零。这也解释了 Cholesky 每步剩余矩阵为何正定。若 $\mathbf{A}$ 本身可能奇异, 不能机械将严格不等号改为非严格; 需要 $\text{range}(\mathbf{B}) \subseteq \text{range}(\mathbf{A})$ 等条件以及伪逆版本。

如果已经分解过 $\mathbf{A}$, 新问题只是在它上面增加少量方向的作用, 是否必须重新分解整个大矩阵? 低秩更新通过消元把新增工作转成小系统, 从而复用原来的求解器。对实矩阵, 设 $\mathbf{A} \in \mathbb{R}^{d \times d}$ 、 $\mathbf{C} \in \mathbb{R}^{k \times k}$ 可逆, $\mathbf{U}, \mathbf{V} \in \mathbb{R}^{d \times k}$ 。若 $\mathbf{S} = \mathbf{C}^{-1} + \mathbf{V}^\top \mathbf{A}^{-1} \mathbf{U}$ 可逆, 则 Woodbury 恒等式给出

$$(\mathbf{A} + \mathbf{U} \mathbf{C} \mathbf{V}^\top)^{-1} = \mathbf{A}^{-1} - \mathbf{A}^{-1} \mathbf{U} (\mathbf{C}^{-1} + \mathbf{V}^\top \mathbf{A}^{-1} \mathbf{U})^{-1} \mathbf{V}^\top \mathbf{A}^{-1}. \quad (6.36)$$

将块矩阵 $\begin{bmatrix} \mathbf{A} & \mathbf{U} \\ -\mathbf{V}^\top & \mathbf{C}^{-1} \end{bmatrix}$ 按两种顺序消元: 先消 $\mathbf{A}$ 得到小系统 $\mathbf{S}$, 先消 $\mathbf{C}^{-1}$ 得到更新矩阵 $\mathbf{A} + \mathbf{U} \mathbf{C} \mathbf{V}^\top$, 其逆的左上块比较便得此式。也可直接乘回验证, 关键恒等式是 $\mathbf{I} - \mathbf{S}^{-1} \mathbf{V}^\top \mathbf{A}^{-1} \mathbf{U} = \mathbf{S}^{-1} \mathbf{C}^{-1}$ 。

特别地, 无 $\mathbf{C}$ 版本只需 $\mathbf{A}$ 与 $\mathbf{I} + \mathbf{V}^\top \mathbf{A}^{-1} \mathbf{U}$ 可逆, 无须对矩形 $\mathbf{U}, \mathbf{V}$ 假定逆。引入 $\mathbf{z} = \mathbf{V}^\top \mathbf{x}$ 后,

$$(\mathbf{I} + \mathbf{V}^\top \mathbf{A}^{-1} \mathbf{U}) \mathbf{z} = \mathbf{V}^\top \mathbf{A}^{-1} \mathbf{b}, \quad \mathbf{x} = \mathbf{A}^{-1} (\mathbf{b} - \mathbf{U} \mathbf{z}),$$

正好是小系统加已有求解器。 $k = 1$ 时得到 Sherman-Morrison 公式

$$(\mathbf{A} + \mathbf{u} \mathbf{v}^\top)^{-1} = \mathbf{A}^{-1} - \frac{\mathbf{A}^{-1} \mathbf{u} \mathbf{v}^\top \mathbf{A}^{-1}}{1 + \mathbf{v}^\top \mathbf{A}^{-1} \mathbf{u}}, \quad 1 + \mathbf{v}^\top \mathbf{A}^{-1} \mathbf{u} \neq 0.$$

同一块行列式的两种消元还给出

$$\det(\mathbf{A} + \mathbf{U} \mathbf{C} \mathbf{V}^\top) = \det \mathbf{A} \det \mathbf{C} \det(\mathbf{C}^{-1} + \mathbf{V}^\top \mathbf{A}^{-1} \mathbf{U}).$$

无 $\mathbf{C}$ 版本为 $\det \mathbf{A} \det(\mathbf{I} + \mathbf{V}^\top \mathbf{A}^{-1} \mathbf{U})$; 行列式恒等式本身即使小系统奇异仍成立, 但求逆公式不能在那时使用。

取 $\mathbf{A} = \text{diag}(2, 3)$ 、 $\mathbf{u} = \mathbf{v} = (1, 1)^\top$ 、 $\mathbf{b} = (1, 0)^\top$ 。直接解 $\begin{bmatrix} 3 & 1 \\ 1 & 4 \end{bmatrix} \mathbf{x} = \mathbf{b}$ 得到 $\mathbf{x} = (4/11, -1/11)^\top$ 。更新公式中的标量为 $1 + \mathbf{u}^\top \mathbf{A}^{-1} \mathbf{u} = 1 + 1/2 + 1/3 = 11/6$, 代回也得到同一解, 并给行列式 $6(11/6) = 11$ 。若原分解已存在, 求 $\mathbf{A}^{-1} \mathbf{U}$ 需要 k 次三角求解, 再处理 k 维系统; 当 $k \ll d$ 时可能有明显收益。低秩更新没有近似原矩阵, 与后面的低秩压缩不同; 小系统若接近奇异, 公式仍可能敏感。

岭型目标 $\|\mathbf{X}\mathbf{w} - \mathbf{y}\|_2^2 + \lambda \|\mathbf{w}\|_2^2$ 在 $\lambda > 0$ 时给出正定系统 $(\mathbf{X}^\top \mathbf{X} + \lambda \mathbf{I})\mathbf{w} = \mathbf{X}^\top \mathbf{y}$, 可用 Cholesky。也可精确改写成增广最小二乘

$$\min_{\mathbf{w}} \left\| \begin{bmatrix} \mathbf{X} \\ \sqrt{\lambda} \mathbf{I} \end{bmatrix} \mathbf{w} - \begin{bmatrix} \mathbf{y} \\ \mathbf{0} \end{bmatrix} \right\|_2^2.$$

这两种写法对应同一个岭目标, 却都不同于未正则化的原问题。选择 λ 是在改变任务设定, 不能仅解释为让分解“成功”的实现细节。

6.3.2.2 正交变换与三角求解

消元改变中间方程的尺度, 另一条路线用正交变换保持欧氏长度。对 $\mathbf{A} \in \mathbb{R}^{m \times d}$ 、 $m \geq d$ 且满列秩, 经济型 QR 分解为 $\mathbf{A} = \mathbf{Q}\mathbf{R}$, 其中 $\mathbf{Q} \in \mathbb{R}^{m \times d}$ 满足 $\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}$, $\mathbf{R} \in \mathbb{R}^{d \times d}$ 可逆上三角。于是

$$\|\mathbf{A}\mathbf{x} - \mathbf{b}\|_2^2 = \|\mathbf{R}\mathbf{x} - \mathbf{Q}^\top \mathbf{b}\|_2^2 + \|(\mathbf{I} - \mathbf{Q}\mathbf{Q}^\top)\mathbf{b}\|_2^2.$$

第二项不随 $\mathbf{x}$ 变化, 而第一项可以通过三角求解 $\mathbf{R}\mathbf{x} = \mathbf{Q}^\top \mathbf{b}$ 降为零。整个过程无需构造 $\mathbf{A}^\top \mathbf{A}$; 这种做法与正规方程法的数值差异, 稍后用条件数解释。

Gram-Schmidt 将每列减去已有正交方向, 再归一化, 在精确算术中给出 QR。稠密计算常用 Householder 反射一次消去一列主对角线下的全部元素。对非零实向量 $\mathbf{a}$, 令 $s = 1$ 当 $a_1 \geq 0$, 否则 $s = -1$, 并取

$$\mathbf{v} = \mathbf{a} + s\|\mathbf{a}\|_2 \mathbf{e}_1, \quad \mathbf{H} = \mathbf{I} - 2 \frac{\mathbf{v}\mathbf{v}^\top}{\mathbf{v}^\top \mathbf{v}}.$$

直接相乘可验 $\mathbf{H}^\top \mathbf{H} = \mathbf{I}$ 、 $\mathbf{H}\mathbf{a} = -s\|\mathbf{a}\|_2 \mathbf{e}_1$ 。符号选择避免在 $\mathbf{v}$ 首元素中相减两个接近的数。每次只作用于剩余子块, 得到 $\mathbf{Q}_{\text{full}}^\top \mathbf{A} = [\mathbf{R}^\top, \mathbf{0}^\top]^\top$; 只存反射向量即可应用 $\mathbf{Q}^\top$, 不必存整个 $m \times m$ 正交矩阵。复数时选相位并使用共轭转置。

例如 $\mathbf{a} = (3, 4)^\top$ 给 $\mathbf{v} = (8, 4)^\top$, $\mathbf{H} = \begin{bmatrix} -3/5 & -4/5 \\ -4/5 & 3/5 \end{bmatrix}$, 确实将 $\mathbf{a}$ 送到 $(-5, 0)^\top$ 。稠密 QR 约需 $2md^2 - 2d^3/3$ 次运算, 多个右端可以复用全部反射与 $\mathbf{R}$ 。秩

亏时仍可得到 QR 表示，却不能直接对奇异 $\mathbf{R}$ 回代；列主元 QR 会重新安排列以辅助判断秩，可靠阈值还需要误差尺度。普通无主元 QR 的某个小对角元本身不是全部数值秩信息。

6.3.3 基于矩阵作用的迭代求解

大规模稀疏矩阵的分解可能产生过多填充，甚至矩阵本身只以“输入向量，返回乘积”的程序给出。这时迭代法 (iterative method) 从初值 $\mathbf{x}^{(0)}$ 出发，通过矩阵向量乘法逐渐修正。定义残差 $\mathbf{r}^{(t)} = \mathbf{b} - \mathbf{A}\mathbf{x}^{(t)}$ 。对方阵，一个基本校正为 $\mathbf{x}^{(t+1)} = \mathbf{x}^{(t)} + \omega \mathbf{r}^{(t)}$ ，相应残差满足 $\mathbf{r}^{(t+1)} = (\mathbf{I} - \omega \mathbf{A})\mathbf{r}^{(t)}$ 。它能否收敛取决于 ω 与矩阵，不能只因每步使用了残差便认定有效。

矩形最小二乘要先把输出残差搬回输入端。目标 $f(\mathbf{w}) = \frac{1}{2} \|\mathbf{X}\mathbf{w} - \mathbf{y}\|_2^2$ 的梯度为 $\mathbf{X}^\top(\mathbf{X}\mathbf{w} - \mathbf{y})$ ，因此

$$\mathbf{w}^{(t+1)} = \mathbf{w}^{(t)} + \eta \mathbf{X}^\top(\mathbf{y} - \mathbf{X}\mathbf{w}^{(t)}). \quad (6.37)$$

每步先计算预测 $\mathbf{X}\mathbf{w}^{(t)}$ ，再用 $\mathbf{X}^\top$ 把输出残差转成系数更新，不必形成 Gram 矩阵；稀疏存储下成本为 $O(\text{nnz}(\mathbf{X}))$ 。伴随搬回残差而非求逆，正是这里出现 $\mathbf{X}^\top$ 的原因。固定步长的收敛范围和初值如何决定选解将在第 6.4.3.2 小节完整证明。

为更充分利用已经做过的矩阵作用，可在

$$\mathcal{K}_k(\mathbf{A}, \mathbf{r}^{(0)}) = \text{span}\{\mathbf{r}^{(0)}, \mathbf{A}\mathbf{r}^{(0)}, \dots, \mathbf{A}^{k-1}\mathbf{r}^{(0)}\}$$

中寻找校正，这称为 Krylov 搜索空间。每多做一次矩阵作用，就得到一个可用于组合的向量；若它不在已有张成空间中，搜索空间就能扩大。每个候选校正量都是这些方向的线性组合，算法再按误差目标选择组合系数。梯度法也可能生成这种空间，故梯度和 Krylov 不是互斥类别。下面用正定和非对称系统说明两种不同的选优准则，不试图穷尽所有矩阵情形。

预条件 (preconditioning) 是为迭代配置一个容易应用的辅助求解器。选可逆 $\mathbf{M}$ ，左预条件解 $\mathbf{M}^{-1}\mathbf{A}\mathbf{x} = \mathbf{M}^{-1}\mathbf{b}$ ，右预条件则令 $\mathbf{x} = \mathbf{M}^{-1}\mathbf{z}$ ，解 $\mathbf{A}\mathbf{M}^{-1}\mathbf{z} = \mathbf{b}$ 。它们不改变精确解，但改变搜索空间与算法读取的残差。实现时只执行 $\mathbf{M}\mathbf{z} = \mathbf{r}$ ，不形成 $\mathbf{M}^{-1}$ 。对角预条件构造和应用便宜，不完全分解保留更多耦合但占用更多存储；总成本应计入构造、每步应用、矩阵作用和迭代次数。选 $\mathbf{M} = \mathbf{A}$ 虽会使变换后的系统简单，却可能已经付出了原求解成本。

6.3.3.1 对称正定条件下的共轭梯度求解

对实对称正定 $\mathbf{A} \in \mathbb{R}^{d \times d}$ ， $\phi(\mathbf{x}) = \frac{1}{2} \mathbf{x}^\top \mathbf{A} \mathbf{x} - \mathbf{b}^\top \mathbf{x}$ 的唯一极小点就是 $\mathbf{x}_* = \mathbf{A}^{-1}\mathbf{b}$ ，且 $\phi(\mathbf{x}) - \phi(\mathbf{x}_*) = \frac{1}{2} \|\mathbf{x} - \mathbf{x}_*\|_{\mathbf{A}}^2$ 。共轭梯度法 (conjugate gradient,

CG) 在 $\mathbf{x}^{(0)} + \mathcal{K}_k(\mathbf{A}, \mathbf{r}^{(0)})$ 中选择这个 $\mathbf{A}$ 加权范数下误差最小的点。与直接沿当前残差走一步不同, 它用 $\mathbf{A}$ 内积正交的方向, 避免破坏已经完成的方向优化。

从任意 $\mathbf{x}^{(0)}$ 计算 $\mathbf{r}^{(0)} = \mathbf{b} - \mathbf{A}\mathbf{x}^{(0)}$ 。若非零, 令 $\mathbf{p}^{(0)} = \mathbf{r}^{(0)}$, 迭代

$$\begin{aligned}\alpha_t &= \frac{(\mathbf{r}^{(t)})^\top \mathbf{r}^{(t)}}{(\mathbf{p}^{(t)})^\top \mathbf{A} \mathbf{p}^{(t)}}, & \mathbf{x}^{(t+1)} &= \mathbf{x}^{(t)} + \alpha_t \mathbf{p}^{(t)}, \\ \mathbf{r}^{(t+1)} &= \mathbf{r}^{(t)} - \alpha_t \mathbf{A} \mathbf{p}^{(t)}, & \beta_t &= \frac{(\mathbf{r}^{(t+1)})^\top \mathbf{r}^{(t+1)}}{(\mathbf{r}^{(t)})^\top \mathbf{r}^{(t)}}, \\ \mathbf{p}^{(t+1)} &= \mathbf{r}^{(t+1)} + \beta_t \mathbf{p}^{(t)}.\end{aligned}$$

若新残差为零即停止, 不再做含零分母的更新。正定性使非零方向的 $(\mathbf{p}^{(t)})^\top \mathbf{A} \mathbf{p}^{(t)} > 0$ 。

这些系数不是任意经验参数。沿 $\mathbf{p}^{(t)}$ 最小化 ϕ 给

$$\alpha_t = \frac{(\mathbf{p}^{(t)})^\top \mathbf{r}^{(t)}}{(\mathbf{p}^{(t)})^\top \mathbf{A} \mathbf{p}^{(t)}}.$$

残差与旧搜索空间正交, 使分子等于 $\|\mathbf{r}^{(t)}\|_2^2$ 。再要求新方向与 $\mathbf{p}^{(t)}$ 在 $\mathbf{A}$ 内积下正交, 结合残差递推及相邻残差正交, 得到上述 β_t 。归纳可核对: 残差彼此正交, 搜索方向彼此 $\mathbf{A}$ 共轭, 而且前 k 个方向张成 $\mathcal{K}_k$ 。此时残差与整个搜索空间正交, 意味着沿空间内任何方向都不能再一阶降低 ϕ ; 正定性进一步保证这就是该空间内唯一的极小点。非零共轭方向必线性无关, 因此精确算术最多 d 步得到精确解。浮点算术中的正交性会受损, 不能把有限步结论当作实现保证。

例如 $\mathbf{A} = \text{diag}(1, 2)$ 、 $\mathbf{b} = (1, 1)^\top$ 、初值为零。第一步 $\alpha_0 = 2/3$, 得到 $\mathbf{x}^{(1)} = (2/3, 2/3)^\top$ 、 $\mathbf{r}^{(1)} = (1/3, -1/3)^\top$; $\beta_0 = 1/9$ 给 $\mathbf{p}^{(1)} = (4/9, -2/9)^\top$ 。第二步 $\alpha_1 = 3/4$ 得到 $\mathbf{x}^{(2)} = (1, 1/2)^\top$, 残差恰为零。每步只需一次矩阵向量乘法、若干内积和向量更新, 额外存储 $O(d)$ 。

预条件 CG 要求 $\mathbf{M}$ 对称正定。若 $\mathbf{M} = \mathbf{L}\mathbf{L}^\top$, 等价的对称系统为 $\mathbf{L}^{-1}\mathbf{A}\mathbf{L}^{-\top}\mathbf{z} = \mathbf{L}^{-1}\mathbf{b}$ 、 $\mathbf{x} = \mathbf{L}^{-\top}\mathbf{z}$ 。左预条件后的 $\mathbf{M}^{-1}\mathbf{A}$ 通常不再对称; 上述换元得到的矩阵仍对称正定, 因而可以直接使用 CG。实现时先计算 $\mathbf{r}^{(0)} = \mathbf{b} - \mathbf{A}\mathbf{x}^{(0)}$; 若它为零就停止。否则解 $\mathbf{M}\mathbf{z}^{(0)} = \mathbf{r}^{(0)}$, 置 $\mathbf{p}^{(0)} = \mathbf{z}^{(0)}$ 与 $\rho_0 = (\mathbf{r}^{(0)})^\top \mathbf{z}^{(0)}$ 。这里的 $\mathbf{z}^{(t)}$ 表示预处理后的残差, 不是上式中的变换坐标。每步取 $\alpha_t = \rho_t / [(\mathbf{p}^{(t)})^\top \mathbf{A} \mathbf{p}^{(t)}]$, 沿用标准 CG 的 $\mathbf{x}^{(t+1)}$ 、 $\mathbf{r}^{(t+1)}$ 更新; 新残差为零时立即停止。否则解 $\mathbf{M}\mathbf{z}^{(t+1)} = \mathbf{r}^{(t+1)}$, 计算 $\rho_{t+1} = (\mathbf{r}^{(t+1)})^\top \mathbf{z}^{(t+1)}$, 再取 $\beta_t = \rho_{t+1} / \rho_t$ 与 $\mathbf{p}^{(t+1)} = \mathbf{z}^{(t+1)} + \beta_t \mathbf{p}^{(t)}$ 。初始方向也必须同步改为预处理后的残差, 不能只替换迭代中的系数。这对应上述变换后内积, 不能配任意非对称预条件器而仍沿用 CG 保证。

6.3.3.2 非对称可逆条件下的 GMRES 求解

非对称矩阵不提供 CG 所需的正定能量，但仍可最小化欧氏残差。广义最小残差法（generalized minimal residual method, GMRES）选择

$$\mathbf{x}^{(k)} = \arg \min_{\mathbf{x} \in \mathbf{x}^{(0)} + \mathcal{K}_k(\mathbf{A}, \mathbf{r}^{(0)})} \|\mathbf{b} - \mathbf{Ax}\|_2.$$

这里允许 $\mathbf{A}$ 不对称，但仍假设它可逆，以便保证每个右端都有唯一解，并证明有限步终止。GMRES 也能用于其他方阵，只是那时要重新讨论是否有解，以及算法会在何种状态下停止。

若 $\gamma = \|\mathbf{r}^{(0)}\|_2 > 0$ ，令 $\mathbf{v}_1 = \mathbf{r}^{(0)}/\gamma$ 。Arnoldi 过程每次计算 $\mathbf{w} = \mathbf{Av}_j$ ，依次减去 $h_{i,j}\mathbf{v}_i$ ，其中 $h_{i,j} = \mathbf{v}_i^* \mathbf{w}$ ，再以剩余长度 $h_{j+1,j}$ 归一化得到 $\mathbf{v}_{j+1}$ 。于是

$$\mathbf{AV}_k = \mathbf{V}_{k+1} \overline{\mathbf{H}}_k, \quad \mathbf{V}_{k+1}^* \mathbf{V}_{k+1} = \mathbf{I}.$$

这里 $\mathbf{V}_k \in \mathbb{F}^{d \times k}$ ， $\overline{\mathbf{H}}_k \in \mathbb{F}^{(k+1) \times k}$ 为上 Hessenberg 矩阵，即主对角线下第二条及更低位置为零。它记录矩阵在逐渐扩大的搜索空间中的作用。候选 $\mathbf{x} = \mathbf{x}^{(0)} + \mathbf{V}_k \mathbf{y}$ 的残差为 $\mathbf{V}_{k+1}(\gamma \mathbf{e}_1 - \overline{\mathbf{H}}_k \mathbf{y})$ ，所以只需解小最小二乘

$$\min_{\mathbf{y} \in \mathbb{F}^k} \|\gamma \mathbf{e}_1 - \overline{\mathbf{H}}_k \mathbf{y}\|_2.$$

可用前述 QR 逐步更新该子问题，而无需解大的正规方程。

例如 $\mathbf{A} = \begin{bmatrix} 1 & 1 \\ 0 & 2 \end{bmatrix}$ 、 $\mathbf{b} = (0, 1)^\top$ 、初值为零。第一步候选为 $(0, t)^\top$ ，残差为 $(-t, 1 - 2t)^\top$ ，最小化 $t^2 + (1 - 2t)^2$ 得到 $t = 2/5$ ，残差范数为 $1/\sqrt{5}$ 。第二步搜索空间已是 $\mathbb{R}^2$ ，得到精确解 $(-1/2, 1/2)^\top$ 。一般可逆矩阵在精确算术中最多 d 步终止；若 Arnoldi 剩余向量提前为零，当前空间已不变，且可逆性保证解已可在其中取得，应先求解当前的小最小二乘问题，取得精确解后停止，无需再归一化零向量。

第 k 步除一次矩阵作用外，还要与 k 个基向量正交化，成本 $O(kd)$ ，存储全部基为 $O(kd)$ 。重启 GMRES 每隔固定步数丢弃旧基并重新开始，降低存储，但丢弃旧方向后，搜索空间不再包含不重启版本已经积累的全部方向，因此可能进展更慢或停滞。采用预条件时，还要明确最小化哪一种残差：左预条件最小化的是 $\|\mathbf{M}^{-1}(\mathbf{b} - \mathbf{Ax})\|_2$ ；右预条件最小化原系统残差，却需将每个搜索方向映回输入。残差小到什么程度足够、递推残差是否可信，还要结合第 6.6.2 小节的条件数、后向误差与重新计算的真实残差判断。

6.4 线性变换的幂与谱分析

求解器的一次更新只是一次变换；应用十次得到什么，与应用次数趋于无穷会怎样，需要分别回答。前一个问题要求计算有限矩阵幂，后一个问题还要研究其中各项的极限。为了把两者放在同一个可算例子里，本节固定

$$\mathbf{A} = \begin{bmatrix} 0.8 & 4 \\ 0 & 0.5 \end{bmatrix}, \quad \mathbf{x}^{(0)} = \begin{bmatrix} 0 \\ 1 \end{bmatrix}, \quad \mathbf{x}^{(k+1)} = \mathbf{A}\mathbf{x}^{(k)}. \quad (6.38)$$

这是 $\mathbb{R}^2$ 到自身的方阵，与近共线设计矩阵是不同对象。第一步 $\mathbf{x}^{(1)} = (4, 0.5)^\top$ 已比初值长得多，但这并不能判断长期是否发散。

6.4.1 特征方向与谱表示

直接相乘会不断混合坐标。若某些方向在作用后保持不变，就可以沿它们分别计算；若找不到足够多这样的方向，则要保留方向间的三角耦合。谱表示的任务是找到这些适合计算的坐标，并说明换坐标是否保留原来的长度。

6.4.1.1 特征方向与不变子空间

在式 (6.38) 中， $\mathbf{A}(1, 0)^\top = 0.8(1, 0)^\top$ ：这条直线只被缩放，没有转向。一般地，方阵 $\mathbf{A} \in \mathbb{F}^{d \times d}$ 若满足

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{v}, \quad \mathbf{v} \neq \mathbf{0}, \quad (6.39)$$

就称 λ 为特征值 (eigenvalue)， $\mathbf{v}$ 为相应特征向量 (eigenvector)。该方向的长度每次乘以 $|\lambda|$ ；实负特征值还使方向反向，复特征值则包含相位变化。实矩阵的全部谱也可能需要在 $\mathbb{C}$ 中描述，例如二维 90 度旋转矩阵的特征值为 $\pm i$ ，没有非零实特征向量，却保留整个实平面。

这提示应同时考虑不变子空间 (invariant subspace) S ，即 $\mathbf{A}S \subseteq S$ 。一维不变子空间给出特征方向，更高维不变子空间允许内部仍有混合。固定 λ 的特征空间为 $\ker(\mathbf{A} - \lambda\mathbf{I})$ ；它包含零向量，非零成员才称特征向量。全部特征值组成的集合记为 $\text{spec}(\mathbf{A})$ ，称为谱。由可逆性判据，特征值恰是特征多项式 (characteristic polynomial)

$$p_{\mathbf{A}}(z) = \det(z\mathbf{I} - \mathbf{A}) \quad (6.40)$$

的根。一个根在特征多项式中的重复次数称为代数重数，相应特征空间的维数称为几何重数。把该特征空间的一组基扩充成全空间的基，矩阵成为左上块 $\lambda\mathbf{I}$ 、左下块为零的分块上三角形式，所以特征多项式至少含相同次数的 $(z - \lambda)$ ：几何重数不超过代数重数。不同特征值的特征向量线性无关，可对一个最短线性依赖式应用 $\mathbf{A} - \lambda\mathbf{I}$ ，消去其中一个非零项而得到矛盾。

即使特征方向不够, Cayley-Hamilton 定理 (Cayley-Hamilton theorem) 仍把高次幂化为有限的低次幂组合。

定理 6.14 Cayley-Hamilton 定理 若 $p_A(z) = z^d + c_{d-1}z^{d-1} + \cdots + c_0$, 则

$$p_A(A) = A^d + c_{d-1}A^{d-1} + \cdots + c_0I = \mathbf{0}.$$

证明. 这里 $\text{adj}(\mathbf{B})$ 表示代数余子式矩阵的转置, 称为古典伴随, 与前面由内积定义的伴随 $\mathbf{B}^*$ 不同。按行列式展开, $\mathbf{B} \text{adj}(\mathbf{B}) = \det(\mathbf{B})\mathbf{I}$, 所以 $(z\mathbf{I} - \mathbf{A}) \text{adj}(z\mathbf{I} - \mathbf{A}) = p_A(z)\mathbf{I}$ 。各余子式至多含 $d-1$ 个一次因子的乘积, 故可将古典伴随写成 $\sum_{j=0}^{d-1} z^j \mathbf{B}_j$ 。比较系数, 得 $\mathbf{B}_{d-1} = \mathbf{I}$ 、 $\mathbf{B}_{j-1} - \mathbf{A}\mathbf{B}_j = c_j\mathbf{I}$ 和 $-\mathbf{A}\mathbf{B}_0 = c_0\mathbf{I}$ 。将中间各式分别左乘 $\mathbf{A}^j$ 后相加, 相邻 $\mathbf{B}_j$ 项抵消, 得到所述等式。 $d=1$ 时直接由首尾两项得到结论。 ■

因此所有高次幂都能化成 $\mathbf{I}, \dots, \mathbf{A}^{d-1}$ 的线性组合, 不要求可对角化。本节的二维矩阵满足 $\mathbf{A}^2 - 1.3\mathbf{A} + 0.4\mathbf{I} = \mathbf{0}$, 所以轨迹满足 $\mathbf{x}^{(k+2)} = 1.3\mathbf{x}^{(k+1)} - 0.4\mathbf{x}^{(k)}$ 。第 14 章还会用这种有限关系判断可达方向何时停止增加。

6.4.1.2 三角化与对角化表示

特征方向不够成基时, 仍能逐步选取相互正交的坐标, 把混合作用限制在上三角部分。

定理 6.15 复 Schur 分解 任意 $\mathbf{A} \in \mathbb{C}^{d \times d}$ 均存在酉矩阵 $\mathbf{Q}$ 和上三角矩阵 $\mathbf{T}$, 使

$$\mathbf{A} = \mathbf{Q}\mathbf{T}\mathbf{Q}^*, \quad \mathbf{Q}^*\mathbf{Q} = \mathbf{I}. \quad (6.41)$$

$\mathbf{T}$ 的对角元为 $\mathbf{A}$ 的特征值, 计入代数重数。

证明. 复特征多项式有根, 取相应单位特征向量 $\mathbf{q}_1$ 并扩充为酉基 $\mathbf{Q}_1$ 。于是 $\mathbf{Q}_1^* \mathbf{A} \mathbf{Q}_1 = \begin{bmatrix} \lambda_1 & \mathbf{a}^* \\ \mathbf{0} & \mathbf{B} \end{bmatrix}$ 。对 $\mathbf{B}$ 按维数归纳作酉三角化, 与第一坐标合并即得 $\mathbf{T}$ 。三角行列式是对角元乘积, 故其特征值正是对角元。 ■

实矩阵也有 $\mathbf{A} = \mathbf{Q}\mathbf{T}\mathbf{Q}^T$ 的实 Schur 形式, 其中 $\mathbf{Q}$ 正交, $\mathbf{T}$ 为分块上三角矩阵, 对角块大小为 1 或 2。非实共轭特征值对应一个实二维不变子空间, 故要由 2×2 块一起表示。这里的 Schur 分解是保持内积的换基, 定义 6.13 中的 Schur 补则是消元后剩余的系数块; 同一个名字不意味着同一种操作。

若有 d 个线性无关特征向量, 将其排成 $\mathbf{V}$, 就进一步得到

$$\mathbf{A} = \mathbf{V}\mathbf{\Lambda}\mathbf{V}^{-1}.$$

这称为对角化 (diagonalization)。在复数域中, 它等价于每个特征值的几何重数等于代数重数。一般相似关系只保持同一算子的代数结构; 酉相似还保持欧氏长度。任意对角化的 $\mathbf{V}$ 未必酉, 坐标变换可能放大误差。

若方向不足, Jordan 形式用广义特征向量补齐。所谓广义特征向量, 是对某个正整数 j 满足 $(\mathbf{A} - \lambda\mathbf{I})^j \mathbf{v} = \mathbf{0}$ 的非零向量。一条链从非零特征向量 $\mathbf{v}_1$ 开始, 满足 $(\mathbf{A} - \lambda\mathbf{I})\mathbf{v}_1 = \mathbf{0}$, 后续向量满足 $(\mathbf{A} - \lambda\mathbf{I})\mathbf{v}_{j+1} = \mathbf{v}_j$ 。在复数域中可取这样的链作基, 使矩阵由块

$$\mathbf{J}_s(\lambda) = \lambda\mathbf{I} + \mathbf{N}, \quad N_{i,i+1} = 1, \quad \mathbf{N}^s = \mathbf{0}$$

组成, 其余 $N_{i,j} = 0$ 。大小 $s > 1$ 的块把“缺少独立特征方向”记录为非零的幂零部分。例如 $\begin{bmatrix} 0.8 & 1 \\ 0 & 0.8 \end{bmatrix}$ 只有一个特征方向; 它不能因为对角元相同就被当成 $0.8\mathbf{I}$ 。Jordan 形式用于解释结构, 数值计算通常采用 Schur 形式, 不主动构造可能极敏感的链基。

三角化还能完成前面留下的矩阵方程条件。对 $\mathbf{AZ} + \mathbf{ZB} = \mathbf{C}$, 分别取 $\mathbf{A} = \mathbf{QTQ}^*$ 、 $\mathbf{B} = \mathbf{USU}^*$, 令 $\mathbf{Y} = \mathbf{Q}^*\mathbf{ZU}$ 、 $\mathbf{D} = \mathbf{Q}^*\mathbf{CU}$, 则

$$\mathbf{TY} + \mathbf{YS} = \mathbf{D}.$$

逐元素有

$$(T_{i,i} + S_{j,j})Y_{i,j} = D_{i,j} - \sum_{k>i} T_{i,k}Y_{k,j} - \sum_{\ell<j} Y_{i,\ell}S_{\ell,j}.$$

按列从左向右、每列自下向上计算, 右侧所需元素已经得到。因此对每个右端唯一可解的充要条件为

$$\lambda_i(\mathbf{A}) + \lambda_j(\mathbf{B}) \neq 0 \quad \text{对所有 } i, j, \quad \text{spec}(\mathbf{A}) \cap \text{spec}(-\mathbf{B}) = \emptyset. \quad (6.42)$$

充分性由上述回代直接给出; 必要性来自这一排序后的线性系统为三角系统, 其行列式是全部 $\lambda_i + \lambda_j$ 的乘积。若有零因子, 线性算子奇异, 便不可能对任意右端都有唯一解。例如标量方程 $2z + (-2)z = c$ 在 $c \neq 0$ 时无解, 在 $c = 0$ 时解不唯一。实块 Schur 形式以小块求解替代逐元素除法, 条件相同。这要求两个矩阵各自可逆; 例如 $\mathbf{A} = \mathbf{0}, \mathbf{B} = \mathbf{I}$ 仍唯一可解。

6.4.1.3 自伴条件下的正交谱表示

Gram 矩阵与二阶导数矩阵的对称性使三角形式中的非对角耦合进一步消失; 后面的协方差矩阵也会具有这种结构。它们不仅有足够特征方向, 还能使这些方向彼此正交²。

² R. A. Horn, C. R. Johnson, *Matrix Analysis*, Cambridge University Press, 2013, 2nd ed.

定理 6.16 自伴矩阵的谱定理 若 $A \in \mathbb{R}^{d \times d}$ 满足 $A^\top = A$, 则全部特征值为实数, 并存在正交矩阵 Q 及实对角矩阵 Λ 使

$$A = Q\Lambda Q^\top. \quad (6.43)$$

复 Hermitian 矩阵 $A^* = A$ 同样有实特征值及酉分解 $A = Q\Lambda Q^*$ 。

证明. 先在复数域取特征对。由 $\mathbf{v}^* A \mathbf{v} = \lambda \mathbf{v}^* \mathbf{v}$, 左侧为实数且 $\mathbf{v}^* \mathbf{v} > 0$, 知 λ 为实数。实对称时, 把 $\mathbf{v}$ 拆成实部和虚部, 至少一个给出非零实特征向量。若 $\mathbf{v}_i, \mathbf{v}_j$ 对应不同特征值, 则

$$\lambda_j \mathbf{v}_i^* \mathbf{v}_j = \mathbf{v}_i^* A \mathbf{v}_j = (A \mathbf{v}_i)^* \mathbf{v}_j = \lambda_i \mathbf{v}_i^* \mathbf{v}_j,$$

从而彼此正交。取单位特征向量 $\mathbf{q}_1$ 。对 $\mathbf{x} \perp \mathbf{q}_1$, $\mathbf{q}_1^* A \mathbf{x} = (A \mathbf{q}_1)^* \mathbf{x} = 0$, 所以其正交补不变, 限制后的算子仍自伴。在该正交补上按维数归纳, 得到其余标准正交特征向量, 与 $\mathbf{q}_1$ 合并即得全空间的基。 ■

若 $\mathbf{x} = \sum_i c_i \mathbf{q}_i$, 则

$$\mathbf{x}^* A \mathbf{x} = \sum_i \lambda_i |c_i|^2. \quad (6.44)$$

因此正定等价于所有特征值正, 半正定等价于所有特征值非负; 正、负特征方向分别给出二次型增大和减小的方向。普通复转置对称 $A^\top = A$ 不够, 例如 $A = iI$ 虽满足转置对称, 特征值却非实。

更一般地, 满足 $A^* A = A A^*$ 的方阵称为正规矩阵 (normal matrix)。复数域中它恰好允许酉对角化: Schur 形式仍正规, 比较第一行与第一列的平方范数可知第一行非对角元全为零, 逐维归纳即得对角形式; 反向由对角矩阵直接验证。自伴矩阵属于这一类。非正规矩阵则不允许这样的正交特征表示, 即使能对角化, 也可能像本节二维例那样通过非正交方向产生短时放大。

这些表示也把第 6.2.4 小节的函数运算落实到谱坐标。若 $A = V \Lambda V^{-1}$, 对定义在其谱上的单值函数 f , 令

$$f(A) = V \operatorname{diag}(f(\lambda_1), \dots, f(\lambda_d)) V^{-1}. \quad (6.45)$$

重复特征值的整个特征空间都乘以同一标量, 故更换其中的基不改变结果。多项式由相似变换的乘法直接满足该式; 收敛幂级数可逐项换基, 也得到相同定义。不可对角化时, 仅给根上的函数值已不够, 还要有块大小所需的导数。对在谱附近解析的 f ,

$$f(J_s(\lambda)) = \sum_{j=0}^{s-1} \frac{f^{(j)}(\lambda)}{j!} N^j. \quad (6.46)$$

这是 Taylor 展开在 $\mathbf{N}^s = \mathbf{0}$ 后精确终止的结果。特别地,

$$e^{tJ} = e^{t\lambda} \sum_{j=0}^{s-1} \frac{t^j}{j!} \mathbf{N}^j.$$

指数中的多项式因子不是数值近似误差, 而是幂零耦合的真实作用。

设标量级数 $\sum_{k \geq 0} a_k z^k$ 的收敛半径为 R , 矩阵的谱半径 (spectral radius) 为 $\rho(\mathbf{A}) = \max_i |\lambda_i(\mathbf{A})|$ 。若 $\rho(\mathbf{A}) < R$, 则矩阵级数绝对收敛。确实, 取 $\rho(\mathbf{A}) < r < R$; Jordan 块的二项式展开表明存在常数 C_r 使 $\|\mathbf{A}^k\| \leq C_r r^k$, 因为有限次多项式增长能被较大的指数 r^k 控制, 零特征值块则在有限步后为零。于是 $\sum_k |a_k| \|\mathbf{A}^k\| \leq C_r \sum_k |a_k| r^k < \infty$ 。这比 $\|\mathbf{A}\| < R$ 的条件更弱。例如本节 $\mathbf{A}$ 的欧氏诱导范数大于 4, 而 $\rho(\mathbf{A}) = 0.8$, 几何级数 $\sum_{k \geq 0} \mathbf{A}^k$ 仍收敛到 $(\mathbf{I} - \mathbf{A})^{-1}$ 。在收敛圆边界上不能只凭谱半径作统一判断。

自伴条件下还能定义非解析于整个复平面的函数。若 $\mathbf{A} \geq 0$, 令 $\mathbf{A}^{1/2} = \mathbf{Q} \text{diag}(\sqrt{\lambda_i}) \mathbf{Q}^*$, 这是唯一的半正定平方根。若另一个半正定 $\mathbf{B}$ 满足 $\mathbf{B}^2 = \mathbf{A}$, 则 $\mathbf{B}$ 与 $\mathbf{A}$ 交换, 在 $\mathbf{A}$ 每个特征空间上仍自伴且满足 $\mathbf{B}^2 = \lambda \mathbf{I}$, 其非负特征值只能为 $\sqrt{\lambda}$, 故该限制等于 $\sqrt{\lambda} \mathbf{I}$, 证明唯一性。这个结论不声称任意平方根唯一, 例如 $\mathbf{I}$ 和 $-\mathbf{I}$ 的平方都是 $\mathbf{I}$ 。

若 $\mathbf{A} > 0$, 还可定义

$$\mathbf{A}^\alpha = \mathbf{Q} \text{diag}(\lambda_i^\alpha) \mathbf{Q}^* \quad (\alpha \in \mathbb{R}), \quad \log \mathbf{A} = \mathbf{Q} \text{diag}(\log \lambda_i) \mathbf{Q}^*.$$

其中 $\alpha = -1/2$ 给逆平方根, $\alpha = 0$ 给恒等矩阵。半正定情形的正实数次幂仍可取 $0^\alpha = 0$, 但负幂和上述实对数被零特征值阻断; 伪逆式截断是另一个定义, 不能暗中代替普通负幂。例如 $\text{diag}(4, 0)$ 有平方根 $\text{diag}(2, 0)$, 却没有普通逆平方根。矩阵指数对任何有限方阵都有定义; 对 $\mathbf{x}'(t) = \mathbf{A}\mathbf{x}(t)$ 逐项求导验证 $\mathbf{x}(t) = e^{t\mathbf{A}}\mathbf{x}(0)$, 连续时间的稳定性分析留到第 13 章。

6.4.2 有限次迭代的计算

现在只固定一个非负整数 k , 不先取极限。逐次计算 $\mathbf{x}^{(k)}$ 需要 k 次矩阵向量乘法, 适合稀疏矩阵且只关心一个初值的情形; 若确需 $\mathbf{A}^k$, 二进制快速幂把矩阵乘法次数降到 $O(\log k)$, 但可能失去稀疏性。谱表示则给出关于 k 的表达式, 用于解释不同初值和步数。

6.4.2.1 可对角化条件下的有限次迭代

对 $\mathbf{A} = \mathbf{V}\mathbf{\Lambda}\mathbf{V}^{-1}$, 相邻 $\mathbf{V}^{-1}\mathbf{V}$ 抵消, 得到

$$\mathbf{A}^k = \mathbf{V}\mathbf{\Lambda}^k\mathbf{V}^{-1}, \quad \mathbf{x}^{(k)} = \sum_i \lambda_i^k c_i \mathbf{v}_i, \quad \mathbf{c} = \mathbf{V}^{-1}\mathbf{x}^{(0)}.$$

式 (6.38) 有特征向量 $\mathbf{v}_1 = (1, 0)^\top$ 、 $\mathbf{v}_2 = (-40/3, 1)^\top$ ，对应 0.8 和 0.5，因而

$$\mathbf{A}^k = \begin{bmatrix} 0.8^k & \frac{40}{3}(0.8^k - 0.5^k) \\ 0 & 0.5^k \end{bmatrix}, \quad \mathbf{x}^{(k)} = \begin{bmatrix} \frac{40}{3}(0.8^k - 0.5^k) \\ 0.5^k \end{bmatrix}. \quad (6.47)$$

$k = 1, 2, 3$ 分别给 $(4, 0.5)^\top$ 、 $(5.2, 0.25)^\top$ 、 $(5.16, 0.125)^\top$ ，与逐步相乘一致。初值实际写成 $\frac{40}{3}\mathbf{v}_1 + \mathbf{v}_2$ ，两个大的横向分量初始相消；两种衰减速度不同，随后相消被打破，因此长度先增大。

一般只有 $\|\mathbf{A}^k\|_2 \leq \|\mathbf{V}\|_2 \|\mathbf{V}^{-1}\|_2 \max_i |\lambda_i|^k$ 。自伴情形 $\mathbf{V}$ 可取酉矩阵，前面的坐标放大因子为 1；非正交特征基则不能忽略该因子。非交换的其他因子也不能混入幂公式： $(\mathbf{BC})^2 = \mathbf{BCBC}$ 一般不等于 $\mathbf{B}^2\mathbf{C}^2$ 。此处能抵消的是相似变换中确实相邻的互逆因子。

6.4.2.2 不可对角化条件下的有限次迭代

对 Jordan 块 $\mathbf{J} = \lambda\mathbf{I} + \mathbf{N}$ ，二项式展开给

$$\mathbf{J}^k = \sum_{j=0}^{\min(k, s-1)} \binom{k}{j} \lambda^{k-j} \mathbf{N}^j, \quad k = 0, 1, \dots \quad (6.48)$$

零次幂按 $\mathbf{J}^0 = \mathbf{I}$ 理解，式中 $\lambda^0 = 1$ ，包括 $\lambda = 0$ ；这样不产生负指数。当 $\lambda = 0$ 时 $\mathbf{J}^k = \mathbf{N}^k$ ， $k \geq s$ 后恰为零。当 $\lambda \neq 0$ 时， $\binom{k}{j}$ 提供至多 $s-1$ 次的多项式因子。

作为与可对角化例的比较，取 $\mathbf{J} = \begin{bmatrix} 0.8 & 1 \\ 0 & 0.8 \end{bmatrix}$ 。对 $k \geq 1$ ， $\mathbf{J}^k = \begin{bmatrix} 0.8^k & k \cdot 0.8^{k-1} \\ 0 & 0.8^k \end{bmatrix}$ ，同一初值 $(0, 1)^\top$ 在第二步成为 $(1.6, 0.64)^\top$ 。若误把该矩阵替换成 $0.8\mathbf{I}$ ，就完全丢掉第一坐标的累积。把式 (6.48) 代入幂级数，按幂零次数收集，又得到式 (6.46)；有限幂与函数表达在这里相互一致。计算中不必为了这一解释去数值识别精确 Jordan 块，微小扰动就可能改变块结构。

6.4.3 长期迭代的极限与收敛

有限步结果总能计算，长期行为却取决于所有不变方向和耦合项。必须区分“对每个初值都衰减”和“某个初值恰好避开了不稳定方向”，也要区分输出不再变化与参数已经收敛。

6.4.3.1 反复作用的衰减与短时放大

定理 6.17 固定矩阵幂的衰减判据 对有限方阵 $\mathbf{A}$ ， $\mathbf{A}^k \rightarrow \mathbf{0}$ 当且仅当 $\rho(\mathbf{A}) < 1$ 。

证明. 若 $A^k \rightarrow 0$, 对任一复特征向量有 $A^k v = \lambda^k v \rightarrow 0$, 故 $|\lambda| < 1$ 。反之, Jordan 表示中每项都是有限次多项式乘以模小于 1 的指数, 因而趋零; 零特征值块最终为零。有限块合并、再乘固定换基矩阵, 仍趋零。 ■

任何诱导范数下 $\|A\| < 1$ 都保证 $\|A^k\| \leq \|A\|^k \rightarrow 0$, 但不是必要条件。固定二维例正是反例: $\|Ae_2\|_2 = \sqrt{16.25} > 4$, 而式 (6.47) 仍逐项趋零。图 6.5 把同一次迭代的轨迹和长度并列, 显示短时放大与长期衰减并不矛盾。




图 6.5 固定二维矩阵的反复作用。初值为 $(0, 1)^T$, 前两步的长度增加, 此后回到原点; 右图将长度与初始长度 1 比较。特征值 0.8 和 0.5 决定长期衰减, 非正交特征方向间的相消则决定早期放大。两图使用同一个矩阵和同一组迭代点。

边界 $\rho = 1$ 也需区分。 $\text{diag}(1, 0.5)^k$ 保留第一坐标而衰减第二坐标, 收敛到一个投影; $\text{diag}(-1, 0.5)^k$ 通常振荡; $\begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix}^k$ 则含线性增长的 k 项。一般矩阵幂有有限极限, 当且仅当每个特征值要么模小于 1, 要么等于 1, 并且特征值 1 的 Jordan 块全为 1×1 ; 此时极限保留 1 特征空间上的分量。若某特征值模大于 1, 至少有初值发散, 不代表每一个初值都发散。

上述结论固定了同一个 A , 不能直接推广到逐步变化的矩阵乘积。例如两个幂零矩阵 $B = \begin{bmatrix} 0 & 2 \\ 0 & 0 \end{bmatrix}$ 、 $C = \begin{bmatrix} 0 & 0 \\ 2 & 0 \end{bmatrix}$ 各自谱半径为零, 而 $BC = \text{diag}(4, 0)$, 交替作用可以增长。自适应迭代和时变系统需要检查整个乘积结构。

6.4.3.2 最小二乘迭代的收敛与选解

对最小二乘, 固定步长使误差更新确实由一个固定自伴矩阵控制。但设计矩阵的零空间不进入残差, 梯度也无法修改其中的初值。为保留常用的样本平均约定, 下面把式 (6.37) 的有效步长写成 η/n 。

定理 6.18 最小二乘梯度迭代的解选择 设非零 $\mathbf{X} \in \mathbb{R}^{n \times d}$, $\mathbf{y} \in \mathbb{R}^n$ 。
对 $F(\mathbf{w}) = \|\mathbf{X}\mathbf{w} - \mathbf{y}\|_2^2 / (2n)$ 使用

$$\mathbf{w}^{(t+1)} = \mathbf{w}^{(t)} - \frac{\eta}{n} \mathbf{X}^\top (\mathbf{X}\mathbf{w}^{(t)} - \mathbf{y}), \quad 0 < \eta < \frac{2n}{\|\mathbf{X}\|_2^2}.$$

任意初值均有

$$\mathbf{w}^{(t)} \longrightarrow \mathbf{X}^\dagger \mathbf{y} + (\mathbf{I} - \mathbf{X}^\dagger \mathbf{X}) \mathbf{w}^{(0)}. \quad (6.49)$$

零初值选择唯一的最小欧氏范数最小二乘解。若进一步满行秩且 $d > n$, 则

$$\hat{\mathbf{w}} = \mathbf{X}^\top (\mathbf{X}\mathbf{X}^\top)^{-1} \mathbf{y}, \quad \{\hat{\mathbf{w}}\} = \arg \min_{\mathbf{X}\mathbf{w}=\mathbf{y}} \|\mathbf{w}\|_2. \quad (6.50)$$

证明. 令 $\mathbf{H} = \mathbf{X}^\top \mathbf{X}$. 它半正定, 且 $\mathbf{z}^\top \mathbf{H} \mathbf{z} = \|\mathbf{X}\mathbf{z}\|_2^2$ 表明 $\ker \mathbf{H} = \ker \mathbf{X}$ 。其最大特征值由单位球上二次型的最大值得到 $\lambda_{\max}(\mathbf{H}) = \|\mathbf{X}\|_2^2$, 这里仅用自伴谱展开与诱导范数定义。定理 6.12 已经从正交几何给出 $\mathbf{w}^\dagger = \mathbf{X}^\dagger \mathbf{y}$, 它满足正规方程 $\mathbf{H}\mathbf{w}^\dagger = \mathbf{X}^\top \mathbf{y}$ 且属于 $(\ker \mathbf{X})^\perp$ 。

令 $\mathbf{e}^{(t)} = \mathbf{w}^{(t)} - \mathbf{w}^\dagger$, 则 $\mathbf{e}^{(t+1)} = (\mathbf{I} - \eta \mathbf{H} / n) \mathbf{e}^{(t)}$ 。在 $\mathbf{H}$ 的正特征值方向 $\mathbf{q}_j$ 上,

$$\mathbf{q}_j^\top \mathbf{e}^{(t)} = \left(1 - \frac{\eta \lambda_j}{n}\right)^t \mathbf{q}_j^\top \mathbf{e}^{(0)} \longrightarrow 0,$$

因为步长条件使倍率绝对值小于 1。在 $\ker \mathbf{X}$ 上倍率为 1, 故保留

$$\mathbf{P}_{\ker \mathbf{X}} \mathbf{w}^{(0)} = (\mathbf{I} - \mathbf{X}^\dagger \mathbf{X}) \mathbf{w}^{(0)}.$$

合并两个正交分量便得到一般极限, 整个证明不需要奇异值分解。

满行秩时全部输出可达, 前述满秩伪逆公式给出 $\hat{\mathbf{w}}$, 全部插值解为

$$\mathbf{w} = \hat{\mathbf{w}} + \mathbf{v}, \quad \mathbf{v} \in \ker \mathbf{X}. \quad (6.51)$$

由于 $\hat{\mathbf{w}} \perp \mathbf{v}$, $\|\mathbf{w}\|_2^2 = \|\hat{\mathbf{w}}\|_2^2 + \|\mathbf{v}\|_2^2$, 只有 $\mathbf{v} = \mathbf{0}$ 达到最小范数。 ■

若 $\mathbf{X} = \mathbf{0}$, 目标与参数无关, 任意步长都保持初值; 零初值仍是最小范数解, 但不能使用分母为零的步长界。例如 $\mathbf{X} = [1 \ 1]$ 、 $\mathbf{y} = 2$ 时, 零初值收敛到 $(1, 1)^\top$; 从 $(3, -1)^\top$ 出发已满足方程, 迭代始终不动。两个解训练拟合相同, 范数不同。步长端点也重要: $\eta = 2n / \|\mathbf{X}\|_2^2$ 时, 最大特征方向的误差倍率为 -1 , 一般振荡而不收敛。

因此损失下降、预测收敛和选出某个参数不是同一陈述。CG 与 GMRES 的系数和搜索空间随步数变化, 不能把它们统一改写成这里的一个固定矩

阵幂；其误差界应在相应优化准则下重新建立。接下来转向另一种任务：不再反复施加同一矩阵，而是只保留其中若干方向。

6.5 线性变换的近似与压缩

一个 $m \times n$ 稠密矩阵需要存储 mn 个数，每次作用需要 $O(mn)$ 次运算。若能以 k 个输入输出方向的配对近似它，存储和作用成本便可降到 $O((m+n)k)$ 。这里把近似矩阵的秩作为规模预算：先规定误差怎样衡量，再决定保留哪些方向。特征向量要求输出回到同一方向，既不适用于矩形矩阵，也不直接解决这个压缩任务。

所需的工具允许输入和输出各选一套正交基，使方向之间只剩非负缩放。

定义 6.19 奇异值分解 矩阵 $A \in \mathbb{F}^{m \times n}$ 的奇异值分解 (singular value decomposition, SVD) 为

$$A = U \Sigma V^*, \quad (6.52)$$

其中 $U \in \mathbb{F}^{m \times m}$ 、 $V \in \mathbb{F}^{n \times n}$ 酉，实数情形为正交矩阵， $\Sigma \in \mathbb{R}^{m \times n}$ 仅主对角元可能非零。令 $q = \min(m, n)$ ，主对角元按 $\sigma_1 \geq \dots \geq \sigma_q \geq 0$ 排列，称为奇异值 (singular value)。正奇异值的个数为 $r = \text{rank}(A)$ 。

存在性由刚建立的自伴谱定理给出。 $A^*A \geq 0$ 有标准正交特征基 $\mathbf{v}_i$ ，正特征值记为 σ_i^2 。对 $\sigma_i > 0$ 定义 $\mathbf{u}_i = A\mathbf{v}_i/\sigma_i$ ，则

$$\mathbf{u}_i^* \mathbf{u}_j = \frac{\mathbf{v}_i^* A^* A \mathbf{v}_j}{\sigma_i \sigma_j} = \delta_{i,j}.$$

零特征值方向满足 $\|A\mathbf{v}_i\|_2^2 = 0$ ，故映为零。把已得 $\mathbf{u}_i$ 补成输出空间的标准正交基，即有完整 SVD。构造同时证明

$$A = \sum_{i=1}^r \sigma_i \mathbf{u}_i \mathbf{v}_i^* = U_r \Sigma_r V_r^*. \quad (6.53)$$

后一种紧致 SVD 的因子尺寸依次为 $m \times r$ 、 $r \times r$ 和 $r \times n$ 。经济型或薄 SVD 保留 q 个方向，尺寸依次为 $m \times q$ 、 $q \times q$ 和 $q \times n$ ，其中仍可能有零奇异值。三种形式都精确表示同一个矩阵，尚未做近似。零矩阵的紧致和为空，完整 SVD 的两套基可任意选择。

几何上， V^* 记录输入方向， Σ 按 σ_i 伸缩， U 把结果送入输出方向。因此

$$\ker A = \text{span}\{\mathbf{v}_{r+1}, \dots, \mathbf{v}_n\}, \quad \text{range}(A) = \text{span}\{\mathbf{u}_1, \dots, \mathbf{u}_r\},$$

前 r 个右奇异向量张成行空间，其余左奇异向量张成左零空间；SVD 因此同时记录了可达输出、被消去的输入，以及与二者正交的方向。对非负自伴矩阵，左右奇异方向可以相同；对不定自伴矩阵，奇异值取特征值的绝对值，符号由左右方向吸收。一般非正规方阵的奇异方向并非特征方向，矩形矩阵甚至没有通常意义的特征值。若若干正奇异值相等，对应左右向量可同步西旋转，分解结果不变；这些相同奇异值对应的整个左右子空间确定，单个基向量却不唯一。

图 6.6 使用二维旋转矩阵 $\mathbf{R}(\theta) = \begin{bmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{bmatrix}$ 构造一个左右方向不同的变换，两侧采用相同比例便于比较伸缩量。




图 6.6 矩阵 $\mathbf{A} = \mathbf{R}(\pi/6) \text{diag}(2, 0.4) \mathbf{R}(\pi/5)^\top$ 将单位圆变为椭圆。蓝、红箭头分别标出右奇异方向 $\mathbf{v}_i$ 及其像 $\sigma_i \mathbf{u}_i$ ；两侧坐标比例相同。奇异值决定长度变化，左右方向可以不同，因而这不是沿特征方向的同空间缩放。图为教学构造。

为看清近共线样本的两个尺度，把式 (6.1) 的输出限制到 $\text{span}\{\mathbf{c}_1, \mathbf{q}\}$ ，用 $\mathbf{c}_1/\sqrt{3}, \mathbf{q}/\sqrt{2}$ 作正交坐标，再将全部输出统一除以 $\sqrt{3}$ ，得到二维表示

$$\mathbf{X}_{\tilde{\epsilon}} = \begin{bmatrix} 1 & 1 \\ 0 & \tilde{\epsilon} \end{bmatrix}, \quad \tilde{\epsilon} = \sqrt{2/3} \epsilon. \quad (6.54)$$

这一统一缩放也把奇异值除以 $\sqrt{3}$ ，不改变它们的比值。原响应 $\mathbf{c}_1 + \delta \mathbf{q}$ 经同样的坐标转换与缩放后，成为 $(1, \sqrt{2/3} \delta)^\top$ 。本节先用这个二维矩阵研究伸缩方向；后面的扰动试验会另选响应 $(2, 0)^\top$ ，以便直接观察响应误差怎样传到系数。

二维 Gram 矩阵为 $G_{\tilde{\varepsilon}} = \begin{bmatrix} 1 & 1 \\ 1 & 1+\tilde{\varepsilon}^2 \end{bmatrix}$, 其两个特征值由二次方程得到

$$\lambda_{\pm} = \frac{2 + \tilde{\varepsilon}^2 \pm \sqrt{4 + \tilde{\varepsilon}^4}}{2}. \quad (6.55)$$

对 $\tilde{\varepsilon} > 0$, $\sigma_{\pm} = \sqrt{\lambda_{\pm}}$; 当 $\tilde{\varepsilon} \rightarrow 0$ 时 $\sigma_{\max} \rightarrow \sqrt{2}$, $\sigma_{\min} \sim \tilde{\varepsilon}/\sqrt{2}$ 。沿最大奇异值对应的输入方向, 两个系数近似同增同减, 输出变化较大; 沿最小奇异值对应的方向, 两个系数近似一增一减, 贡献相消, 输出变化很小。这个推导用于理解谱, 不建议为计算小奇异值显式形成 Gram 矩阵, 也不建议直接用相近两数相减计算 λ_{-} ; 后面的误差分析会解释原因。

现在可以把已定义的伪逆写成奇异坐标形式:

$$A^{\dagger} = V_r \Sigma_r^{-1} U_r^* = \sum_{i=1}^r \sigma_i^{-1} v_i u_i^*. \quad (6.56)$$

这个公式实现的仍是先前的最小残差、最小范数选择: 先去掉输出中与值域正交的分量, 再把沿 u_i 的分量除以 σ_i 并映回 v_i 。得到的输入位于零空间的正交补中, 也就是先前构造伪逆时选择的子空间。当重复奇异值使基改变时, 同步旋转保持上式不变。小 σ_i 在正向作用中压缩, 在反求中则放大噪声。

若要把方向变化与非负伸缩分成两步, 不必保留两套坐标矩阵的全部信息。

定义 6.20 极分解与部分等距因子 矩阵 $A \in \mathbb{F}^{m \times n}$ 的规范极分解 (polar decomposition) 为

$$A = QH, \quad H = (A^* A)^{1/2}, \quad (6.57)$$

其中 $H \geq 0$, Q 在 $(\ker A)^{\perp}$ 上保持长度, 并在 $\ker A$ 上取零。这样的 Q 称为相应的部分等距因子。

紧致 SVD 给出 $H = V_r \Sigma_r V_r^*$, $Q = U_r V_r^*$, 故 $Q^* Q = P_{(\ker A)^{\perp}}$, $Q Q^* = P_{\text{range}(A)}$ 。 H 由唯一半正定平方根确定, Q 在 $\text{range}(H)$ 上被 $A = QH$ 确定, 在其正交补取零, 因而也唯一。可逆方阵时 Q 酉; 秩亏时它不是整个输入空间的等距映射。若维数允许把 Q 进一步延拓到零空间, 原矩阵并不规定零方向的像, 延拓可能不唯一。例如 $\text{diag}(2, 0)$ 的规范 $Q = \text{diag}(1, 0)$, 而正交延拓 $\text{diag}(1, 1)$ 和 $\text{diag}(1, -1)$ 乘以同一 H 都给原矩阵。极分解常用于形状对齐和正交约束计算, 不应把这种延拓自由误认为规范部分等距因子也不唯一。

SVD 还补齐第 6.2.3 节中范数的谱表达。因为酉矩阵保持欧氏长度，且迹可循环换序，

$$\|\mathbf{A}\|_2 = \max_{\|\mathbf{x}\|_2=1} \|\mathbf{A}\mathbf{x}\|_2 = \sigma_1, \quad (6.58)$$

$$\|\mathbf{A}\|_F = (\text{tr}(\mathbf{A}^* \mathbf{A}))^{1/2} = \left(\sum_i \sigma_i^2 \right)^{1/2}, \quad (6.59)$$

$$\|\mathbf{A}\|_* := \sum_i \sigma_i. \quad (6.60)$$

最后一项是核范数 (nuclear norm)，将各奇异尺度线性相加。这里下标 * 表示矩阵核范数，不是先前对任意向量范数的抽象对偶记号；恰好相对于 Frobenius 配对，它又是谱范数的对偶。

定义 6.21 Schatten 范数 对 $1 \leq p < \infty$ ，Schatten p 范数 (Schatten p -norm) 为 $\|\mathbf{A}\|_{S_p} = (\sum_i \sigma_i^p)^{1/p}$ ；对 $p = \infty$ 取 $\|\mathbf{A}\|_{S_\infty} = \sigma_1$ ，零矩阵的值为零。

$p = 1, 2, \infty$ 依次给核范数、Frobenius 范数和谱范数。在输入和输出两端换用酉基时，奇异值不变，这些范数也不变；它们衡量的是沿各奇异方向的伸缩量，而不取决于方向在坐标中怎样排列。 $0 < p < 1$ 沿用同一公式得到的是拟范数：对 $\mathbf{A} = \text{diag}(1, 0)$ 、 $\mathbf{B} = \text{diag}(0, 1)$ ， $\|\mathbf{A} + \mathbf{B}\|_{S_p} = 2^{1/p} > 2$ ，违反三角不等式。行分组混合范数则依赖坐标，并不属于这个族。

对 $p \geq 1$ ，三角不等式可以由矩阵配对的对偶形式理解。两个同尺寸矩阵有 $|\text{tr}(\mathbf{B}^* \mathbf{A})| \leq \sum_i \sigma_i(\mathbf{B}) \sigma_i(\mathbf{A})$ 。具体地，将两者都展开成奇异向量之和，取绝对值后，配对系数为两套左右内积绝对值的乘积；由 Cauchy-Schwarz，它们的各行和、各列和不超过 1。将权重依次分配给降序排列的最大奇异值，就得到上述上界。再用标量 Hölder 不等式，得到 Schatten 配对界。反向取与 $\mathbf{A}$ 同奇异方向、奇异值按标量对偶上界的达到条件选取的 $\mathbf{B}$ ，可得

$$\|\mathbf{A}\|_{S_p} = \max_{\|\mathbf{B}\|_{S_q} \leq 1} |\text{tr}(\mathbf{B}^* \mathbf{A})|, \quad 1/p + 1/q = 1.$$

线性配对的最大值满足三角不等式；正定性与齐次性由奇异值直接验证。 $p = 1$ 的情形因而证明了核范数确实是范数。范数是凸函数，所以把它加入优化目标，可以用凸惩罚限制奇异值的总量。

对秩为 r 的矩阵，标量范数比较给

$$\|\mathbf{A}\|_2 \leq \|\mathbf{A}\|_F \leq \sqrt{r} \|\mathbf{A}\|_2, \quad \|\mathbf{A}\|_F \leq \|\mathbf{A}\|_* \leq \sqrt{r} \|\mathbf{A}\|_F. \quad (6.61)$$

范数等价仍带有秩相关常数。特别是多个方向都被舍弃时，最坏方向误差和总平方误差不能用同一个舍弃奇异值替代。

6.5.1 规模约束下的最优误差近似

先固定秩预算 k ，在所有秩不超过 k 的矩阵中寻找最小误差。“保留最大的 k 个奇异值”需要证明，因为候选并不限于删去原分解中的若干项，还可以采用任意新的方向。为证明最优性，先比较单位输入沿各方向产生多大的输出，再比较一组正交输入方向的总平方输出。

方向长度不同会干扰这种比较。例如对 $\mathbf{X}^*\mathbf{X}$ ，二次型 $\mathbf{x}^*\mathbf{X}^*\mathbf{X}\mathbf{x} = \|\mathbf{X}\mathbf{x}\|_2^2$ 随输入长度一起增大。除以输入的平方长度后，才得到同一尺度下的方向强度。

定义 6.22 Rayleigh 商 对自伴矩阵 $\mathbf{A}$ 和非零向量 $\mathbf{x}$,

$$R_{\mathbf{A}}(\mathbf{x}) = \frac{\mathbf{x}^*\mathbf{A}\mathbf{x}}{\mathbf{x}^*\mathbf{x}} \quad (6.62)$$

称为 Rayleigh 商 (Rayleigh quotient)，即单位平方长度对应的二次型强度。

除以长度后，同一方向的不同缩放得到同一数值；这让方向之间可以比较。

定理 6.23 Rayleigh–Ritz 变分原理 设自伴 $\mathbf{A}$ 的特征值降序排列为 $\lambda_1 \geq \dots \geq \lambda_d$ ，则

$$\lambda_d = \min_{\mathbf{x} \neq 0} R_{\mathbf{A}}(\mathbf{x}), \quad \lambda_1 = \max_{\mathbf{x} \neq 0} R_{\mathbf{A}}(\mathbf{x}). \quad (6.63)$$

两端分别由最小、最大特征值的非零特征向量达到。

证明. 写 $\mathbf{x} = \sum_i c_i \mathbf{q}_i$ ，谱定理给 $R_{\mathbf{A}}(\mathbf{x}) = \sum_i \lambda_i |c_i|^2 / \sum_i |c_i|^2$ 。它是特征值的凸组合，位于两端之间；取相应特征向量即达到端点。■

例如 $R_{\mathbf{X}^*\mathbf{X}}(\mathbf{z}) = \|\mathbf{X}\mathbf{z}\|_2^2 / \|\mathbf{z}\|_2^2$ ，所以近共线 Gram 矩阵的 λ_- 确实量化最弱输入方向，不只是特征多项式的一个根。

只取一个方向可以找到最大或最小值。若保留 i 维空间，可以先问其中最弱方向有多强，再选择使这个最弱值尽量大的子空间。这样才能刻画中间的第 i 个特征值。

定理 6.24 Courant–Fischer 极小极大原理 在上述降序约定下，对 $i = 1, \dots, d$,

$$\lambda_i = \max_{\dim S=i} \min_{\substack{\mathbf{x} \in S \\ \mathbf{x} \neq 0}} R_{\mathbf{A}}(\mathbf{x}) = \min_{\dim T=d-i+1} \max_{\substack{\mathbf{x} \in T \\ \mathbf{x} \neq 0}} R_{\mathbf{A}}(\mathbf{x}). \quad (6.64)$$

证明. 记 $E_i = \text{span}\{\mathbf{q}_1, \dots, \mathbf{q}_i\}$, $F_i = \text{span}\{\mathbf{q}_i, \dots, \mathbf{q}_d\}$. 任意 i 维 S 与 F_i 有非零交向量, 其 Rayleigh 商不超过 λ_i , 所以第一个极值不超过 λ_i ; 取 $S = E_i$ 时, 所有非零向量的商都不小于 λ_i , 等号达到. 任意 $d-i+1$ 维 T 与 E_i 也有非零交向量, 其商不小于 λ_i , 故第二个极值不小于 λ_i ; 取 $T = F_i$ 时, 所有商不超过 λ_i , 再次达到等号. ■

为了证明多个方向合起来能保留多少平方输出, 还需要比较 k 个单位正交方向的二次型之和. 把这些方向作为矩阵的列, 求和就可以写成迹. 若 $\mathbf{W}^* \mathbf{W} = \mathbf{I}_k$, 把各列展开到特征基, 令 $p_i = \sum_{j=1}^k |(\mathbf{q}_i^* \mathbf{W})_j|^2$, 则 $0 \leq p_i \leq 1$, $\sum_i p_i = k$, 且 $\text{tr}(\mathbf{W}^* \mathbf{A} \mathbf{W}) = \sum_i \lambda_i p_i$. 将权重从小特征值方向移到尚未饱和的大特征值方向, 不会减小目标, 因此

$$\max_{\mathbf{W}^* \mathbf{W} = \mathbf{I}_k} \text{tr}(\mathbf{W}^* \mathbf{A} \mathbf{W}) = \sum_{i=1}^k \lambda_i.$$

前 k 个特征向量达到上界. 若边界特征值相等, 可以在重特征空间中改变所保留的方向; 最佳值确定, 并不自动给唯一子空间.

若二次型代表惩罚, 则希望这些方向的惩罚总和最小, 而非最大. 列间正交约束仍不能省, 否则可以反复选择同一个低代价方向, 无法保留 k 维空间.

定理 6.25 正交列约束下的迹最小化 设实对称 $\mathbf{B}$ 的特征值在本定理中按升序记为 $\lambda_1 \leq \dots \leq \lambda_d$, 对应标准正交特征向量为 $\mathbf{u}_i$. 对 $1 \leq k \leq d$,

$$\min_{\substack{\mathbf{H} \in \mathbb{R}^{d \times k} \\ \mathbf{H}^\top \mathbf{H} = \mathbf{I}_k}} \text{tr}(\mathbf{H}^\top \mathbf{B} \mathbf{H}) = \sum_{i=1}^k \lambda_i. \quad (6.65)$$

前 k 个特征向量达到最小值. 若 $k < d$ 且 $\lambda_k < \lambda_{k+1}$, 最优列空间唯一, 但其正交基仍可右乘任意 $k \times k$ 正交矩阵.

证明. 令 $\mathbf{C} = \mathbf{U}^\top \mathbf{H}$, 则 $\mathbf{C}^\top \mathbf{C} = \mathbf{I}_k$, $\mathbf{C} \mathbf{C}^\top$ 为秩 k 的正交投影, 其对角元 $p_i = \sum_j c_{i,j}^2$ 满足 $0 \leq p_i \leq 1$ 及 $\sum_i p_i = k$. 对 $k < d$,

$$\sum_i \lambda_i p_i - \sum_{i=1}^k \lambda_i = \sum_{i \leq k} \lambda_i (p_i - 1) + \sum_{i > k} \lambda_i p_i \geq (\lambda_{k+1} - \lambda_k) \sum_{i > k} p_i \geq 0.$$

取前 k 个方向使 p_i 依次为 1 与 0, 达到下界. 有严格间隙时, 等号要求所有 $i > k$ 的 $p_i = 0$, 故列空间必须为所述子空间. $k = d$ 时 $\mathbf{H}$ 方阵正交, 迹恒为 $\text{tr}(\mathbf{B})$. ■

例如 $\mathbf{B} = \text{diag}(0, 1, 4)$, $k = 2$ 时最小迹是 1. 若只要求每列单位长度, 两列都取 $(1, 0, 0)^\top$ 会得到 0, 但它们只张成一维, 已不满足原来的规模约束.

误差几何改变时, 单位方向也会改变。若成本是 $\mathbf{x}^\top \mathbf{B}\mathbf{x}$, 收益是 $\mathbf{x}^\top \mathbf{A}\mathbf{x}$, 应比较单位成本下的收益。

定义 6.26 对称正定矩阵对的广义特征值 设 $\mathbf{A}^\top = \mathbf{A}$, $\mathbf{B}^\top = \mathbf{B} > 0$ 。非零 $\mathbf{v}$ 满足

$$\mathbf{A}\mathbf{v} = \lambda \mathbf{B}\mathbf{v} \quad (6.66)$$

时, $\lambda, \mathbf{v}$ 称为矩阵对的广义特征值与广义特征向量。求解它们称为广义特征值问题 (generalized eigenvalue problem), 相应广义 Rayleigh 商为 $R_{\mathbf{A}, \mathbf{B}}(\mathbf{x}) = \mathbf{x}^\top \mathbf{A}\mathbf{x} / (\mathbf{x}^\top \mathbf{B}\mathbf{x})$ 。

对 $\mathbf{A} = \mathbf{B} = \text{diag}(4, 1)$, 该商恒为 1; 误用欧氏分母则得到从 1 到 4 的范围, 改变了任务的成本定义。

取 Cholesky 分解 $\mathbf{B} = \mathbf{L}\mathbf{L}^\top$ 并令 $\mathbf{z} = \mathbf{L}^\top \mathbf{x}$, 可将商改写成

$$R_{\mathbf{A}, \mathbf{B}}(\mathbf{x}) = \frac{\mathbf{z}^\top (\mathbf{L}^{-1} \mathbf{A} \mathbf{L}^{-\top}) \mathbf{z}}{\mathbf{z}^\top \mathbf{z}}.$$

中间矩阵对称, 故所有广义特征值实, 且 Rayleigh–Ritz 和 Courant–Fischer 原理在加权几何下成立。取其正交特征向量 $\mathbf{z}_i$, 映回 $\mathbf{v}_i = \mathbf{L}^{-\top} \mathbf{z}_i$, 就有 $\mathbf{v}_i^\top \mathbf{B}\mathbf{v}_j = \delta_{i,j}$ 。因此约束 $\mathbf{W}^\top \mathbf{B}\mathbf{W} = \mathbf{I}_k$ 下的迹最大、最小值也分别是最大的、最小的 k 个广义特征值之和。证明只需代入 $\mathbf{Z} = \mathbf{L}^\top \mathbf{W}$ 并应用刚证的普通迹极值。理论上也可用 $\mathbf{z} = \mathbf{B}^{1/2} \mathbf{x}$ 和 $\mathbf{B}^{-1/2} \mathbf{A} \mathbf{B}^{-1/2}$; 计算中用三角求解实施换元, 不显式形成逆平方根。 $\mathbf{B}$ 若仅半正定, 非零方向上分母可能为零; 若不定, 分母可能变号, 甚至出现无穷或复广义特征值, 不能照搬正定最值结论。

回到普通欧氏误差。定义截断 SVD (truncated SVD)

$$\mathbf{A}_k = \sum_{i=1}^k \sigma_i \mathbf{u}_i \mathbf{v}_i^*, \quad 0 \leq k < r, \quad (6.67)$$

其中 $k = 0$ 为空和。这一候选在两种常用误差下确实都最优³。

定理 6.27 Eckart–Young–Mirsky 定理 对 $0 \leq k < r = \text{rank}(\mathbf{A})$,

$$\min_{\text{rank}(\mathbf{B}) \leq k} \|\mathbf{A} - \mathbf{B}\|_2 = \sigma_{k+1}, \quad (6.68)$$

$$\min_{\text{rank}(\mathbf{B}) \leq k} \|\mathbf{A} - \mathbf{B}\|_F = \left(\sum_{i=k+1}^r \sigma_i^2 \right)^{1/2}. \quad (6.69)$$

两个最小值均由 $\mathbf{A}_k$ 达到; $k \geq r$ 时取 $\mathbf{A}_k = \mathbf{A}$, 最小误差为零。

³ C. Eckart, G. Young, *The Approximation of One Matrix by Another of Lower Rank* In *Psychometrika*, 1936, vol. 1, no. 3, pp. 211–218

证明. 任取秩不超过 k 的 B . $S = \text{span}\{\mathbf{v}_1, \dots, \mathbf{v}_{k+1}\}$ 为 $k+1$ 维, 而 $\dim \ker B \geq n - k$, 故二者有非零交向量. 取其中单位向量 $\mathbf{x} = \sum_{i=1}^{k+1} c_i \mathbf{v}_i$, 则

$$\|(A - B)\mathbf{x}\|_2 = \|\mathbf{Ax}\|_2 = \left(\sum_{i=1}^{k+1} \sigma_i^2 |c_i|^2 \right)^{1/2} \geq \sigma_{k+1}.$$

这给所有候选的谱误差下界. $A - A_k$ 的最大奇异值恰为 σ_{k+1} , 故下界达到.

对 Frobenius 误差, 令 $C = U^* B V$, 其列空间的正交投影为 P . 酉不变性及 $PC = C$ 给

$$\|A - B\|_F^2 = \|\Sigma - C\|_F^2 = \|(I - P)\Sigma\|_F^2 + \|P\Sigma - C\|_F^2.$$

这里按列使用了正交分解. 第一项为原矩阵的 Frobenius 范数平方减去投影保留的范数平方, 而 $\|P\Sigma\|_F^2 = \sum_{i=1}^q \sigma_i^2 \|P\mathbf{e}_i\|_2^2$. 权重在 $[0, 1]$ 内, 总和不超过 $\text{tr } P \leq k$. 依照迹最大化的权重论证, 它不超过 $\sum_{i=1}^k \sigma_i^2$, 所以误差平方至少为舍弃奇异值的平方和 $\sum_{i>k} \sigma_i^2$. 取 C 为截断后的 Σ 使第二项为零, 并保留前 k 个方向, 同时达到该下界. ■

用谱范数衡量近似误差时, 要找出所有单位输入中最大的输出误差; 用 Frobenius 范数时, 则对一组标准正交输入分别计算输出误差, 再把平方求和后开方. 它们的最优值不同, 不能只说“截断误差等于小奇异值”. 例如 $\text{diag}(2, 0.4)$ 的秩一误差在两种范数下恰好都是 0.4, 因为只舍弃一个方向. 若舍弃多个方向, 谱范数仍只取其中最大的奇异值, Frobenius 范数则要累加所有被舍弃奇异值的平方. 其他加权、逐元素或分组误差需要重新核对最优性, 不能自动沿用这个定理.

Frobenius 目标在 $1 \leq k < r$ 且 $\sigma_k > \sigma_{k+1}$ 时的最佳矩阵唯一: 严格间隙使最优保留子空间唯一, 证明中的第二个平方项为零又确定其投影结果. 边界相等时可能有多个最佳矩阵. 谱目标即使有严格间隙也未必唯一, 例如 $\text{diag}(2 + t, 0)$ 对 $|t| \leq 0.4$ 都以谱误差 0.4 近似 $\text{diag}(2, 0.4)$. 对近共线 $\mathbf{X}_{\tilde{\epsilon}}$ 取 $k = 1$, 两种误差都是 $\sigma_{\min} \sim \tilde{\epsilon}/\sqrt{2}$. 若第二个方向的输出量已小于数据误差, 就很难仅凭现有数据确认这个方向; 若它仍包含能够可靠测量的信号, 舍弃它便会丢失这部分信息.

矩阵压缩也可以用于样本特征: 只保存每个样本的 k 个坐标, 再用这些坐标重构原特征. 下面把这个任务写成刚才的低秩近似问题. 设 $\mathbf{X} \in \mathbb{R}^{n \times d}$ 每行是一个样本, 先减去样本均值, 使每列之和为零. 选择 $\mathbf{W}^\top \mathbf{W} = \mathbf{I}_k$, 低维坐标为 $\mathbf{Z} = \mathbf{XW}$, 重构为 $\hat{\mathbf{X}} = \mathbf{ZW}^\top$, 且

$$\|\mathbf{X} - \mathbf{XWW}^\top\|_F^2 = \|\mathbf{X}\|_F^2 - \|\mathbf{XW}\|_F^2 = \|\mathbf{X}\|_F^2 - \text{tr}(\mathbf{W}^\top \mathbf{X}^\top \mathbf{XW}).$$

迹极值说明取前 k 个右奇异向量即最小化重构误差, 且重构恰为 $\mathbf{X}_k$ 。这就是主成分分析 (principal component analysis, PCA) 的有限矩阵形式。 $n \geq 2$ 时, 样本协方差 $\mathbf{X}^T \mathbf{X} / (n-1)$ 使保留方差总和为 $\|\mathbf{XW}\|_F^2 / (n-1)$, 所以最大化保留样本方差与最小化当前数据的平方重构误差等价。

例如取四个中心化样本

$$(2, 0), \quad (-2, 0), \quad (0, 1), \quad (0, -1).$$

Gram 矩阵为 $\text{diag}(8, 2)$ 。取 $k = 1$ 得到 $\mathbf{W} = (1, 0)^T$, 坐标为 $(2, -2, 0, 0)^T$, 后两个样本都重构成零, 误差平方为 2。未中心化时, 最强方向可能反映数据整体离原点的位置, 而非围绕均值的变化; 重构原始数据还应加回均值。若把某一项特征的单位从米改成毫米, 这项特征在平方误差中的权重就会增大。因此是否对各项特征标准化, 必须由任务怎样比较不同特征的误差来决定。最大样本方差不自动等于最有预测价值的方向, 对总体协方差的估计保证则需要后续统计假设。

有时不直接指定 k , 而是在拟合目标中加 $\lambda \|\mathbf{B}\|_*$, 或限制 $\mathbf{B} = \mathbf{LR}^T$ 以避免存储大矩阵。前者通过惩罚改变目标, 后者用因子列数限制可行秩; 它们都不能不加说明地当成同一个固定秩截断问题。核范数与因子平方惩罚之间确有一个精确联系。

引理 6.28 核范数的因子分解表达 设 $\mathbf{A} \in \mathbb{R}^{m \times n}$, $r = \text{rank}(\mathbf{A})$ 。对任意正整数 $q \geq r$,

$$\|\mathbf{A}\|_* = \min_{\substack{\mathbf{L} \in \mathbb{R}^{m \times q}, \mathbf{R} \in \mathbb{R}^{n \times q} \\ \mathbf{LR}^T = \mathbf{A}}} \frac{1}{2} (\|\mathbf{L}\|_F^2 + \|\mathbf{R}\|_F^2). \quad (6.70)$$

证明. 对非零 $\mathbf{A}$, 写紧致 SVD 为 $\mathbf{P}\Sigma\mathbf{Q}^T$ 。取 $\mathbf{L} = \mathbf{P}\Sigma^{1/2}$ 、 $\mathbf{R} = \mathbf{Q}\Sigma^{1/2}$, $q > r$ 时补零列, 则乘积为 $\mathbf{A}$, 两侧平方范数均为 $\sum_i \sigma_i$, 所以右侧最小值不超过核范数。反过来, 令 $\mathbf{C} = \mathbf{PQ}^T$, 则 $\|\mathbf{C}\|_2 = 1$ 。任意可行因子满足

$$\begin{aligned} \|\mathbf{A}\|_* &= \text{tr}(\mathbf{C}^T \mathbf{A}) = \langle \mathbf{C}^T \mathbf{L}, \mathbf{R} \rangle_F \\ &\leq \|\mathbf{C}^T \mathbf{L}\|_F \|\mathbf{R}\|_F \leq \|\mathbf{L}\|_F \|\mathbf{R}\|_F \leq \frac{1}{2} (\|\mathbf{L}\|_F^2 + \|\mathbf{R}\|_F^2). \end{aligned}$$

依次使用 Frobenius 的 Cauchy-Schwarz、混合次乘性和 $2ab \leq a^2 + b^2$ 。零矩阵时取零因子达到零, 下界由非负性保证。■

例如 $\text{diag}(4, 1)$ 的平衡因子均为 $\text{diag}(2, 1)$, 每侧 Frobenius 范数的平方为 5, 平均后仍为核范数 5。把一侧乘 c 、另一侧除以 c 虽不改变乘积, 却一般增加两侧的平方范数之和, 这解释了“平衡”的含义。若 $q < r$, 精确乘积约束不可行。因子目标关于两侧的联合变量仍非凸, 恒等式不保证任

意因子算法达到全局最优。即使直接解 $\min_{\mathbf{B}} \frac{1}{2} \|\mathbf{A} - \mathbf{B}\|_F^2 + \lambda \|\mathbf{B}\|_*$, 所得也是奇异值收缩 $(\sigma_i - \lambda)_+$ 而非原值截断: 由奇异方向对齐后的逐标量最小化可验证。惩罚参数控制收缩幅度, 其产生的秩还取决于原谱, 不等于直接指定 k 。

6.5.2 误差约束下的最优规模近似

若系统规定输出误差不能超过 τ , 应反过来求最小可行秩。记 $\sigma_{r+1} = 0$, 定义两条最优误差曲线 $e_2(k) = \sigma_{k+1}$ 、 $e_F(k) = (\sum_{i>k} \sigma_i^2)^{1/2}$, $k = 0, \dots, r$ 。上一小节已经证明它们不是某个启发式算法的误差, 而是所有该规模候选的最低误差。因此对 $\tau \geq 0$,

$$k_2(\tau) = \min\{k \in \{0, \dots, r\} : \sigma_{k+1} \leq \tau\} = \#\{i : \sigma_i > \tau\}, \quad (6.71)$$

$$k_F(\tau) = \min\left\{k \in \{0, \dots, r\} : \sum_{i>k} \sigma_i^2 \leq \tau^2\right\}. \quad (6.72)$$

截断 SVD 在这两个最小整数上提供可行解; 任何更小秩都被最优误差下界排除。当阈值恰好等于某奇异值时, “不超过” 允许舍弃该方向, 故计数用严格大于。 $\tau = 0$ 时需要代数秩, $\tau \geq \|\mathbf{A}\|$ 时相应目标允许秩零。负阈值不可行。相对误差可令 $\tau = \epsilon \|\mathbf{A}\|$, 但零矩阵应直接处理, 不能计算 $0/0$ 。

例如奇异值为 $(8, 3, 1, 0.2)$ 时, 秩 0 至 4 的谱误差为 $(8, 3, 1, 0.2, 0)$, Frobenius 误差为 $(\sqrt{74.04}, \sqrt{10.04}, \sqrt{1.04}, 0.2, 0)$ 。阈值 $\tau = 1$ 在谱范数下只需 $k = 2$, 在 Frobenius 范数下却需 $k = 3$, 因为两个被舍弃方向合计的平方误差为 $1.04 > 1$ 。图 6.7 用同一谱展示两种读取方式。

以紧致因子存储 $\mathbf{A}_k$ 需要约 $(m+n)k + k$ 个数, 作用于一个输入可先算 $\mathbf{V}_k^* \mathbf{x}$ 、按 σ_i 缩放、再乘 $\mathbf{U}_k$ 。只有当 k 相对两端维数足够小时, 才真正节省存储和计算; 小矩阵中因子开销可能更大。求 SVD 本身也有成本, 不能只统计后续乘法。噪声尺度若高于最后保留的奇异值, 把 k 算得很精确也不等于方向可辨认, 这需要下一节的谱隙条件。

秩还有几种用途不同的替代尺度。代数秩严格计算非零奇异值个数, 对任意小的秩增加扰动都可能跳变。给定绝对阈值 τ 的数值秩 (numerical rank) $r_{\text{num}}(\mathbf{A}; \tau) = \#\{i : \sigma_i > \tau\}$, 在这里等于谱范数误差阈值下的最优秩; 若采用相对阈值, 必须同时说明所乘尺度, 不能把 “数值秩” 当成一个不含容差的固定数值。

数值秩需要指定一个硬阈值, 越过阈值就增加一个方向。如果希望连续地描述伸缩作用集中在多少方向, 可以把全部平方奇异值之和除以最强方向的平方奇异值。这就是稳定秩的思路。




图 6.7 固定奇异值 (8, 3, 1, 0.2) 的最优误差曲线。给定横轴的秩可读出最低误差；给定水平误差阈值则寻找第一个满足要求的整数秩。 $\tau = 1$ 时，蓝色谱误差在 $k = 2$ 达标，红色 Frobenius 误差要到 $k = 3$ 才达标。连线只辅助阅读，可行秩为整数。

定义 6.29 稳定秩 非零矩阵 $\mathbf{A}$ 的稳定秩 (stable rank) 为

$$r_{\text{stable}}(\mathbf{A}) = \frac{\|\mathbf{A}\|_{\text{F}}^2}{\|\mathbf{A}\|_2^2} = \frac{\sum_i \sigma_i^2}{\sigma_1^2}. \quad (6.73)$$

零矩阵另约定为零。

对非零矩阵，它在 $[1, r]$ 内，所有非零奇异值相等时取 r ，平方奇异值之和主要由首方向贡献时接近 1。它在非零矩阵处连续且不随整体缩放改变，但在零矩阵处的上述约定不使它连续。近共线例有 $r_{\text{stable}}(\mathbf{X}_{\varepsilon}) = 1 + \lambda_- / \lambda_+ \rightarrow 1$ ，而 $\varepsilon > 0$ 时的代数秩始终为 2。

稳定秩是有效秩 (effective rank) 的一种。另一种常用定义先令 $p_i = \sigma_i / \sum_j \sigma_j$ ，再定义 $r_{\text{ent}} = \exp(-\sum_i p_i \log p_i)$ ，约定 $0 \log 0 = 0$ ；也有用平方奇异值归一化的版本，其值一般不同。这些量可以连续变化，描述奇异值集中在多少方向；它们不直接回答给定误差阈值下至少要保留几个方向。例如上述四个奇异值的稳定秩是 $74.04/64 \approx 1.157$ ，既不是 $\tau = 1$ 时的 2，也不是 3。它也不同于第 5 章随正则化尺度变化的核有效维度 $d_{\text{eff}}(\lambda)$ 。

各层变换还满足 $\|\mathbf{A}_L \cdots \mathbf{A}_1\|_2 \leq \prod_{\ell=1}^L \|\mathbf{A}_{\ell}\|_2$ ，但逐层最强方向未必能对齐，上界可能宽松；稳定秩不能按同一方式简单相乘。由此也可见，规模指标、最优误差与实际可辨认信息是不同结论。接下来需要问：数据或计算发生微小变化时，这些答案还可靠吗？

6.6 线性变换的扰动与稳定性

前面假定矩阵与右端数据精确已知。实际任务中，测量先使输入偏离理想值，算法又可能在计算时引入舍入或迭代误差。我们要分别追踪这两类误差：反求系数时，输出误差会被放大多少；压缩矩阵时，保留的方向会转动多少；计算幂、指数或平方根时，函数值会改变多少。虽然逆和幂也都是矩阵函数，但这几项任务评价的结果不同，需要各自的误差尺度与条件。

6.6.1 误差度量与传播

设目标映射为 F ，理想输入为 z ，实际交给算法的是 $z + \Delta z$ ，算法返回 $\hat{y}$ 。一个确定的误差分解是

$$\hat{y} - F(z) = \underbrace{\hat{y} - F(z + \Delta z)}_{\text{计算误差}} + \underbrace{F(z + \Delta z) - F(z)}_{\text{输入变化引起的误差}}.$$

第一项评价算法对当前输入的计算，第二项评价问题对输入的敏感性。即使算法精确算出了当前输入的答案，第二项也可能很大；因此检查求解器的同时，还要检查问题本身对输入有多敏感。以下讨论算法时，将实际输入重新记为 z ，以免每式都携带相同的扰动下标。

例如反求线性模型系数时，一种评价是比较计算系数与精确系数的差；另一种评价是问，只需把给定数据改动多少，计算系数就能成为改动后问题的精确解？前者直接比较答案，后者把计算偏差解释为等效输入改动。前向误差（forward error）是 $\hat{y} - F(z)$ 的大小；后向误差（backward error）则寻找能使 $\hat{y} = F(z + \delta z)$ 成立的最小允许输入变化。允许改变哪些分量、用什么范数和是否保持结构，都是定义的一部分。例如只允许改右端与同时改矩阵，得到的线性系统后向误差不同；若要求扰动矩阵仍对称，其最小值也可能不同。

若 F 在所讨论邻域内可微，一阶变化为 $F(z + \delta z) - F(z) = DF(z)[\delta z] + o(\|\delta z\|)$ 。绝对局部条件数为导数算子范数 $\|DF(z)\|$ ；当 $z \neq 0$ 且 $F(z) \neq 0$ 时，相对局部条件数为 $\|DF(z)\| \|z\| / \|F(z)\|$ 。它们描述扰动足够小时的一阶最坏放大。要评价一个给定大小的扰动，还需控制高阶余项，或直接建立有限扰动界。如果输出为零，应报告绝对误差或明确的任务尺度；秩变化等不连续处不能强行使用微分。

计算模型也要写明。排除上溢、下溢及无效运算后，舍入到最近可表示数的基本运算常满足

$$\text{fl}(a \circ b) = (a \circ b)(1 + \delta), \quad |\delta| \leq u, \quad (6.74)$$

其中 $\circ$ 是加、减、乘或合法除法， u 为单位舍入误差。IEEE 双精度通常有 $u = 2^{-53}$ 。这个模型比较的是当前浮点操作数的精确运算结果，并不

消除操作数本身已有的误差；两个近数相减时，这些误差相对于微小差值会很大。次正规数、上溢、除以零等需另处理。累积 n 个舍入因子常用 $\gamma_n = nu/(1 - nu)$ 控制，前提是 $nu < 1$ ，所以“误差是 u 量级”仍要核对维数和传播系数。

定义 6.30 范数意义下的后向稳定 设输入空间给定范数。若算法对声明的非零输入类返回 $\hat{y} = F(z + \delta z)$ ，并在充分小的 u 下满足 $\|\delta z\|/\|z\| \leq Cu$ ，其中 C 不依赖 u ，则称其在此误差口径下后向稳定 (backward stability)。必须说明 C 对问题规模及输入类的依赖；零输入另用绝对误差口径。

后向稳定说明算法只引入小的等效输入扰动。若条件数也适中，一阶分析便给小前向误差；条件数很大时，两者可以同时出现：算法很好地解了一个邻近问题，结果却离当前问题的精确答案很远。下面用逆与线性系统把这一关系变成可计算的公式。

6.6.2 逆值的扰动与稳定性

逆和伪逆的变化，会直接影响反求系数的结果。我们先研究可逆方阵 A 的普通逆，再研究按最小范数规则唯一选定的 Moore–Penrose 伪逆；一般不唯一的广义逆不在这里的比较范围内。令 E 为矩阵扰动，若 $\alpha = \|A^{-1}\|\|E\| < 1$ ，则

$$A + E = A(I + A^{-1}E)$$

可逆，因为 $\sum_{j \geq 0} (-A^{-1}E)^j$ 绝对收敛并为右侧括号的逆。利用逆的差恒等式，得到

$$(A + E)^{-1} - A^{-1} = -(A + E)^{-1}EA^{-1}, \quad \|(A + E)^{-1} - A^{-1}\| \leq \frac{\|A^{-1}\|^2\|E\|}{1 - \alpha}. \quad (6.75)$$

条件 $\alpha < 1$ 保证扰动后矩阵仍可逆；当 α 接近 1 时，分母变小，这个误差上界也随之增大，说明可逆性的保证已接近其适用边界。 $\alpha \geq 1$ 只表示该保证失效，不意味着扰动后的矩阵必定奇异。

定义 6.31 可逆矩阵的条件数 对同一向量范数诱导的矩阵范数，可逆方阵 A 的条件数 (condition number) 为

$$\kappa(A) = \|A\|\|A^{-1}\|. \quad (6.76)$$

$\|I\| = 1$ 及次乘性保证 $\kappa \geq 1$ 。欧氏情形由 SVD 给出

$$\kappa_2(A) = \frac{\sigma_{\max}(A)}{\sigma_{\min}(A)}. \quad (6.77)$$

酉矩阵的条件数为 1，接近奇异时条件数增大。将式 (6.75) 除以 $\|\mathbf{A}^{-1}\|$ ，便得到相对逆值误差不超过 $\kappa(\mathbf{A})(\|\mathbf{E}\|/\|\mathbf{A}\|)/(1 - \kappa(\mathbf{A})\|\mathbf{E}\|/\|\mathbf{A}\|)$ 。它量化的是逆值变化，不只是某一个右端的求解误差。

满秩矩形矩阵常记 $\kappa_2 = \sigma_1/\sigma_q$ ， $q = \min(m, n)$ 。秩亏矩阵在允许任意秩变化的反演问题中通常约定条件数为无穷；固定矩阵后，伪逆线性映射却仍有有限范数 $\|\mathbf{A}^\dagger\|_2 = 1/\sigma_r$ ($r > 0$)，零矩阵的伪逆范数为零。这里讨论的是两个不同问题：改变矩阵可能增加秩，使伪逆突然改变；固定矩阵、只改变右端时，则是应用一个已经确定的线性映射 $\mathbf{A}^\dagger$ 。两者的敏感性不能用同一个结论代替。

在秩保持的区域，伪逆也有有限扰动控制。令 $\mathbf{B} = \mathbf{A} + \mathbf{E}$ 。用 Penrose 投影恒等式整理可得精确关系

$$\begin{aligned}\mathbf{B}^\dagger - \mathbf{A}^\dagger &= -\mathbf{B}^\dagger \mathbf{E} \mathbf{A}^\dagger \\ &\quad + \mathbf{B}^\dagger (\mathbf{B}^\dagger)^* \mathbf{E}^* (\mathbf{I} - \mathbf{A} \mathbf{A}^\dagger) \\ &\quad + (\mathbf{I} - \mathbf{B}^\dagger \mathbf{B}) \mathbf{E}^* (\mathbf{A}^\dagger)^* \mathbf{A}^\dagger.\end{aligned}$$

可先把差写成 $-\mathbf{B}^\dagger \mathbf{E} \mathbf{A}^\dagger + \mathbf{B}^\dagger (\mathbf{I} - \mathbf{A} \mathbf{A}^\dagger) - (\mathbf{I} - \mathbf{B}^\dagger \mathbf{B}) \mathbf{A}^\dagger$ ，再用 $\mathbf{B}^* = \mathbf{A}^* + \mathbf{E}^*$ 及正交投影消去对应零空间项，验证上式。投影范数不超过 1，故若两者秩同为 $r > 0$ ，且最小正奇异值都不小于 $s_0 > 0$ ，则

$$\|\mathbf{B}^\dagger - \mathbf{A}^\dagger\|_2 \leq (\|\mathbf{B}^\dagger\|_2 \|\mathbf{A}^\dagger\|_2 + \|\mathbf{B}^\dagger\|_2^2 + \|\mathbf{A}^\dagger\|_2^2) \|\mathbf{E}\|_2 \leq \frac{3\|\mathbf{E}\|_2}{s_0^2}. \quad (6.78)$$

只要保持秩且扰动足够小，原来的最小正奇异值就仍与零隔开；后面会用奇异值扰动界给出可选的共同下界 s_0 。若秩改变，这个统一下界可能消失。例如 $\mathbf{A} = \text{diag}(1, 0)$ 、 $\mathbf{B}_\epsilon = \text{diag}(1, \epsilon)$ 趋向同一个 $\mathbf{A}$ ，却有 $\mathbf{B}_\epsilon^\dagger = \text{diag}(1, \epsilon^{-1})$ 不趋向 $\mathbf{A}^\dagger = \text{diag}(1, 0)$ 。把零奇异方向置零不保证邻近非零方向也稳定。

逆值敏感性传到求解时，还要计入右端。设 $\mathbf{A}\mathbf{x} = \mathbf{b} \neq 0$ ，扰动系统为 $(\mathbf{A} + \mathbf{E})(\mathbf{x} + \Delta\mathbf{x}) = \mathbf{b} + \Delta\mathbf{b}$ 。相减得 $\mathbf{A}\Delta\mathbf{x} = \Delta\mathbf{b} - \mathbf{E}\mathbf{x} - \mathbf{E}\Delta\mathbf{x}$ 。取范数、将最后一项吸收到左侧，并用 $\|\mathbf{b}\| \leq \|\mathbf{A}\| \|\mathbf{x}\|$ ，得到

$$\frac{\|\Delta\mathbf{x}\|}{\|\mathbf{x}\|} \leq \frac{\kappa(\mathbf{A})}{1 - \kappa(\mathbf{A})\|\mathbf{E}\|/\|\mathbf{A}\|} \left(\frac{\|\mathbf{E}\|}{\|\mathbf{A}\|} + \frac{\|\Delta\mathbf{b}\|}{\|\mathbf{b}\|} \right), \quad \|\mathbf{A}^{-1}\| \|\mathbf{E}\| < 1. \quad (6.79)$$

只改右端时， $\Delta\mathbf{x} = \mathbf{A}^{-1}\Delta\mathbf{b}$ ，上界退化为 $\kappa(\mathbf{A})\|\Delta\mathbf{b}\|/\|\mathbf{b}\|$ 。它是最坏方向界，不是每个扰动都达到的倍数。伪逆选解也可直接拆成 $\mathbf{B}^\dagger(\mathbf{b} + \Delta\mathbf{b}) - \mathbf{A}^\dagger\mathbf{b} = (\mathbf{B}^\dagger - \mathbf{A}^\dagger)\mathbf{b} + \mathbf{B}^\dagger\Delta\mathbf{b}$ ，再结合式 (6.78)；零输出时应保留绝对界，不盲目除以解范数。

近共线例把系数敏感性与拟合敏感性分开。对二维表示 $\mathbf{X}_{\tilde{\epsilon}}$ 另取响应 $\mathbf{y}_0 = (2, 0)^\top$, 原解为 $\boldsymbol{\beta}_0 = (2, 0)^\top$; 改为 $\mathbf{y}_0 + (0, \eta)^\top$ 后,

$$\boldsymbol{\beta}_0 + \Delta\boldsymbol{\beta} = \begin{bmatrix} 2 - \eta/\tilde{\epsilon} \\ \eta/\tilde{\epsilon} \end{bmatrix}. \quad (6.80)$$

响应相对变化 $|\eta|/2$, 系数相对变化 $|\eta|/(\sqrt{2}\tilde{\epsilon})$; $\kappa_2(\mathbf{X}_{\tilde{\epsilon}}) = \sqrt{\lambda_+/\lambda_-} \sim 2/\tilde{\epsilon}$ 。这些系数都是精确解。系数的大幅变化来自数据变化与矩阵近共线性, 即使求解器没有任何误差也会出现。




图 6.8 近共线矩阵的精确敏感性。固定 $\mathbf{y}_0 = (2, 0)^\top$, 扰动为 $(0, 10^{-4})^\top$; 红线是响应相对扰动 5×10^{-5} , 蓝线是系数相对变化 $10^{-4}/(\sqrt{2}\tilde{\epsilon})$ 。双对数坐标显示列越接近, 反求系数越敏感; 图中没有数值求解误差。

一般最小二乘在固定 $\mathbf{X}$ 下的拟合值是 $\hat{\mathbf{y}} = \mathbf{X}\mathbf{X}^\dagger \mathbf{y} = \mathbf{P}_\mathbf{X} \mathbf{y}$, 故 $\|\Delta\hat{\mathbf{y}}\|_2 \leq \|\Delta\mathbf{y}\|_2$ 。系数变化却是 $\mathbf{X}^\dagger \Delta\mathbf{y}$, 可由小正奇异值放大。这个界比较的是同一训练矩阵 $\mathbf{X}$ 上的拟合值; 若 $\mathbf{X}$ 也改变, 对应列空间和投影也可能改变, 需要另外控制。新输入 $\mathbf{a}$ 上的预测变化为 $\mathbf{a}^\top \mathbf{X}^\dagger \Delta\mathbf{y}$, 绝对值由 $\|(\mathbf{X}^\dagger)^\top \mathbf{a}\|_2 \|\Delta\mathbf{y}\|_2$ 控制。新样本可能不遵循训练数据的近共线关系, 因此外推仍可敏感。

抑制弱方向会同时改变估计。截断伪逆只保留 $\sigma_i > \tau$ 的项, 把其余逆因子置零; 对固定截断算子, 右端放大不超过 $1/\tau$ ($\tau > 0$)。但截断阈值附近若有奇异值跨越, 算子本身又可能跳变。岭解 $\hat{\boldsymbol{\beta}}_\lambda = (\mathbf{X}^\top \mathbf{X} + \lambda \mathbf{I})^{-1} \mathbf{X}^\top \mathbf{y}$ 将逆因子替换为

$$\frac{\sigma_i}{\sigma_i^2 + \lambda}, \quad \lambda > 0. \quad (6.81)$$

由于 $\sigma_i^2 + \lambda \geq 2\sigma_i\sqrt{\lambda}$, 其最大放大不超过 $1/(2\sqrt{\lambda})$; 训练拟合在该方向上则乘以 $\sigma_i^2/(\sigma_i^2 + \lambda) < 1$, 引入收缩偏差。零奇异方向两种方法都给零, 不能恢复已被数据消去的信息。参数 λ 和阈值 τ 还随特征单位变化, 不能脱离数据缩放比较。

计算结果是否可信, 需要可计算的检验量。先设 $\mathbf{A}$ 可逆, 算法给 $\hat{\mathbf{x}}$, 定义残差 (residual)

$$\mathbf{r} = \mathbf{b} - \mathbf{A}\hat{\mathbf{x}}. \quad (6.82)$$

因 $\mathbf{x} - \hat{\mathbf{x}} = \mathbf{A}^{-1}\mathbf{r}$, $\mathbf{b} \neq 0$ 时

$$\frac{\|\hat{\mathbf{x}} - \mathbf{x}\|}{\|\mathbf{x}\|} \leq \kappa(\mathbf{A}) \frac{\|\mathbf{r}\|}{\|\mathbf{b}\|}.$$

例如 $\mathbf{A} = \text{diag}(1, \epsilon)$ 、 $\mathbf{b} = (1, \epsilon)^\top$, $0 < \epsilon \ll 1$ 。真解 $(1, 1)^\top$ 与候选 $(1, 0)^\top$ 的相对误差为 $1/\sqrt{2}$, 残差 $(0, \epsilon)^\top$ 的相对大小却是 $\epsilon/\sqrt{1 + \epsilon^2} \rightarrow 0$ 。矩阵的 $\kappa_2 = 1/\epsilon$ 正好解释了差别。小残差说明方程几乎满足, 不说明弱方向的参数已经求准。

若只允许改右端, $\mathbf{A}\hat{\mathbf{x}} = \mathbf{b} - \mathbf{r}$ 给出相对后向误差 $\|\mathbf{r}\|_2/\|\mathbf{b}\|_2$ 。 $\mathbf{b} = 0$ 时不要加一个任意小常数造分母, 可报告绝对残差, 或采用联合扰动定义。

定义 6.32 线性系统的范数型相对后向误差 对 $\mathbf{A} \in \mathbb{R}^{m \times n}$ 、 $\mathbf{b} \in \mathbb{R}^m$ 与候选 $\hat{\mathbf{x}}$, 令

$$\eta_2(\hat{\mathbf{x}}; \mathbf{A}, \mathbf{b}) = \min \left\{ \epsilon \geq 0 : \begin{array}{l} (\mathbf{A} + \Delta\mathbf{A})\hat{\mathbf{x}} = \mathbf{b} + \Delta\mathbf{b}, \\ \|\Delta\mathbf{A}\|_2 \leq \epsilon\|\mathbf{A}\|_2, \quad \|\Delta\mathbf{b}\|_2 \leq \epsilon\|\mathbf{b}\|_2 \end{array} \right\},$$

其中最小化也遍历满足条件的 $\Delta\mathbf{A}, \Delta\mathbf{b}$, 不另要求结构保持。

令 $d_0 = \|\mathbf{A}\|_2\|\hat{\mathbf{x}}\|_2 + \|\mathbf{b}\|_2$ 。 $d_0 > 0$ 时有闭式

$$\eta_2 = \frac{\|\mathbf{r}\|_2}{d_0}.$$

证明先由 $\Delta\mathbf{A}\hat{\mathbf{x}} - \Delta\mathbf{b} = \mathbf{r}$ 及三角不等式得到下界。若 $\hat{\mathbf{x}} \neq 0$, 取

$$\Delta\mathbf{A} = \frac{\|\mathbf{A}\|_2}{d_0} \frac{\mathbf{r}\hat{\mathbf{x}}^\top}{\|\hat{\mathbf{x}}\|_2}, \quad \Delta\mathbf{b} = -\frac{\|\mathbf{b}\|_2}{d_0} \mathbf{r},$$

两者恰好按分母的两项分配残差, 达到下界。若 $\hat{\mathbf{x}} = 0$ 且 $d_0 > 0$, 取 $\Delta\mathbf{A} = 0, \Delta\mathbf{b} = -\mathbf{r}$ 即可; 若 $d_0 = 0$, 必有 $\mathbf{b} = 0$ 和 $\mathbf{A}\hat{\mathbf{x}} = 0$, 约定 $\eta_2 = 0$ 。对可逆系统, 可把这个联合后向误差代入式 (6.79), 当 $\kappa\eta_2 < 1$ 时得到前向误差上界 $2\kappa\eta_2/(1 - \kappa\eta_2)$ 。

上面的矩形后向误差衡量“成为邻近精确方程的解”，并不是最小二乘算法的完整评价。当目标输出不在列空间中，最小二乘的最优解也会留下非零方程残差。因此要检查的首先是正规方程残差 $\mathbf{g} = \mathbf{X}^*(\mathbf{y} - \mathbf{X}\hat{\mathbf{x}})$ ；秩亏时还需检查 $\mathbf{P}_{\ker \mathbf{X}}\hat{\mathbf{x}} = \mathbf{0}$ 才能确认最小范数选择。例如 $\mathbf{X} = [1 \ 1]$ 、 $\mathbf{y} = 2$ 的候选 $(3, -1)^\top$ 方程残差为零，却不是伪逆解 $(1, 1)^\top$ 。对固定正秩矩阵，候选在行空间内的解误差最多为 $\|\mathbf{g}\|_2/\sigma_r^2$ ，零空间分量另计；这是将正规方程限制到行空间后求逆的结果。正规方程残差检查拟合误差是否已最小，零空间分量则检查是否按约定选择了最小范数输入。

这些界使直接法的数值区别有了明确含义。带部分主元 LU 在浮点中通常表现良好，但后向误差受消元增长影响。若定义增长因子为消元过程中最大元素绝对值除以原矩阵最大元素绝对值，则典型误差界含维数、 u 及该因子；它在特殊矩阵上可以很大。主元选取控制计算过程，不能改善原问题的条件数。Householder QR 通过近正交变换工作，具有相应的范数型后向误差界；经典 Gram-Schmidt 在近相关列上可能丢失正交性，改进形式或重正交化才有不同保证。不能只因精确公式中写着 $\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}$ 就认定计算出的基满足同样等式。

Cholesky 在正定、无异常算术并成功完成时有良好的后向误差性质。接近半正定边界时，舍入可能造成非正主元；失败既可能反映真实非正定，也可能反映尺度与计算误差。添加对角常数会改变任务，需有明确正则化依据。满秩矩阵的正规方程满足

$$\kappa_2(\mathbf{X}^\top \mathbf{X}) = \kappa_2(\mathbf{X})^2, \quad (6.83)$$

因为特征值是奇异值平方。近共线例使条件数从 $2/\varepsilon$ 量级升为 $4/\varepsilon^2$ 量级；当 ε^2 已小于舍入尺度，形成 $1 + \varepsilon^2$ 甚至可能直接丢掉区分两列的信息。QR 与 SVD 不显式形成 Gram 矩阵，避免这一额外损失，但不能消除原始小奇异值带来的敏感性。岭问题虽然可对 $\mathbf{X}^\top \mathbf{X} + \lambda \mathbf{I}$ 作 Cholesky，高精度要求时仍可使用前面建立的增广最小二乘与 QR。

迭代法还需要把精确算术的收敛与有限精度的停止分开。对对称正定 $\mathbf{A}$ ，CG 在 $\mathbf{x}^{(0)} + \mathcal{K}_k$ 中最小化 $\mathbf{A}$ 加权误差；这个搜索空间中任意候选的误差可写成 $p_k(\mathbf{A})\mathbf{e}^{(0)}$ ， p_k 次数不超过 k 且 $p_k(0) = 1$ 。因此

$$\frac{\|\mathbf{e}^{(k)}\|_{\mathbf{A}}}{\|\mathbf{e}^{(0)}\|_{\mathbf{A}}} \leq \min_{\substack{\deg p \leq k \\ p(0)=1}} \max_{\lambda \in \text{spec}(\mathbf{A})} |p(\lambda)|.$$

令 $a = \lambda_{\min} > 0, b = \lambda_{\max}$ 。若 $a < b$ ，选择 $p(\lambda) = T_k((a+b-2\lambda)/(b-a))/T_k((a+b)/(b-a))$ ，其中 $T_k(\cos \theta) = \cos(k\theta)$ 为 Chebyshev 多项式。它

在 $[a, b]$ 上的分子绝对值不超过 1; 利用 $x > 1$ 时 $T_k(x) = ((x + \sqrt{x^2 - 1})^k + (x - \sqrt{x^2 - 1})^k)/2$, 得到经典界

$$\|e^{(k)}\|_A \leq 2 \left(\frac{\sqrt{\kappa_2(A)} - 1}{\sqrt{\kappa_2(A)} + 1} \right)^k \|e^{(0)}\|_A. \quad (6.84)$$

$a = b$ 时 $A = aI$, 一次更新就精确求解。这个界只利用谱端点; 特征值聚簇时, 在实际谱点上选多项式可给更快收敛。采用正定预条件 M 后, 对称化系统 $M^{-1/2}AM^{-1/2}$ 的条件数进入同一证明, 不应在普通欧氏内积中把一般非对称的 $M^{-1}A$ 直接当作自伴矩阵。

GMRES 相应控制 $\|r^{(k)}\|_2 / \|r^{(0)}\|_2 \leq \min_{p(0)=1, \deg p \leq k} \|p(A)\|_2$ 。非正规矩阵的这一范数不由特征值模单独决定; 对角化时还出现特征向量基的放大因子, 与本章短时放大例中的问题相同。重启、预条件和有限精度又会改变实际进展。预条件的总成本应包括构造、每次辅助求解及存储, 不能只比较迭代步数。

停止时应按任务检查真实残差、相对后向误差及条件数估计; 用递推公式更新的残差可能积累舍入误差, 因此应适时从当前解重新计算 $b - A\hat{x}$, 必要时使用更高精度求残差。以该残差解校正方程并更新解称为迭代改进, 它仍依赖分解精度、条件数和残差精度, 不能保证任意病态问题都恢复准确解。若数据本身的误差已超过迭代残差, 继续降低计算残差也不恢复缺失信息。

方法	结构与主要成本	精度及停止时的区别
带主元 LU	可逆方阵; 分解约 $2d^3/3$, 每右端 $O(d^2)$	后向误差含主元增长; 小残差仍需结合条件数
QR	满列秩最小二乘; 稠密分解 $O(md^2)$, 可复用反射	避免形成 Gram 矩阵; 秩判断需列主元或其他分析
Cholesky	正定方阵; 约 $d^3/3$, 利用对称存储	核对正定余量; 半正定退化不直接适用
SVD 与伪逆	任意矩形; 稠密分解成本通常高于 QR	明示小奇异值; 截断要报告阈值和偏差
共轭梯度	对称正定; 每步矩阵作用与少量向量存储	A 加权误差受谱和预条件影响; 重算真实残差
GMRES	本节用于非对称可逆方阵; 基存储随步数增加	最小残差不等于最小解误差; 重启可停滞

表 6.2 在同一求解任务中比较结构、成本与可靠性。稀疏分解还需计入填充, 迭代法还需计入预条件成本; 任何稳定实现都不能消除输入问题本身的敏感性。

需要整个逆的许多元素时, 可以从稳定分解计算并检验逆; 若只需要 $A^{-1}b$ 、 $b^T A^{-1}b$ 或 $A^{-1}U$, 应用求解器通常已足够。Woodbury 等精确恒等式也应通过内层求解实施并检查条件, 不能凭等式简短就推断浮点误差较小。

6.6.3 谱值与方向的扰动与稳定性

压缩误差由奇异值决定, 但压缩方向由子空间决定; 前者稳定不保证后者稳定。比较方向之前还要排除基选择的任意性。单个特征向量可改符号或

复相位, 重复谱值中的整组基还可以旋转; 逐列相减会把这些无实质变化的选择也计作误差。

例如同一直线用 $\mathbf{q}$ 或 $-\mathbf{q}$ 表示, 列向量差很大, 直线却没有改变。因此要比较子空间本身的夹角, 并让比较结果与空间内部的基选择无关。

定义 6.33 等维子空间的主角 设 $\mathbf{Q}, \tilde{\mathbf{Q}} \in \mathbb{F}^{d \times r}$ 均有标准正交列, $1 \leq r \leq d$ 。其列空间之间的主角 (principal angles) $0 \leq \theta_1 \leq \dots \leq \theta_r \leq \pi/2$ 由 $\mathbf{Q}^* \tilde{\mathbf{Q}}$ 的奇异值 $\cos \theta_1, \dots, \cos \theta_r$ 定义。记 $\boldsymbol{\Theta} = \text{diag}(\theta_i)$, $\sin \boldsymbol{\Theta} = \text{diag}(\sin \theta_i)$ 。

因为 $\mathbf{Q}^*, \tilde{\mathbf{Q}}$ 都是收缩映射, 上述奇异值位于 $[0, 1]$ 。换用两子空间内部的酉基只会在 $\mathbf{Q}^* \tilde{\mathbf{Q}}$ 两端乘酉矩阵, 不改变奇异值, 故主角确实只依赖子空间。一维时 $\theta = \arccos |\mathbf{q}^* \tilde{\mathbf{q}}|$, 绝对值消去符号或相位歧义。令 $\mathbf{P} = \mathbf{Q} \mathbf{Q}^*$, $\tilde{\mathbf{P}} = \tilde{\mathbf{Q}} \tilde{\mathbf{Q}}^*$, 则

$$\begin{aligned} \|\mathbf{P} - \tilde{\mathbf{P}}\|_2 &= \|(\mathbf{I} - \mathbf{P}) \tilde{\mathbf{Q}}\|_2 = \|\sin \boldsymbol{\Theta}\|_2 = \sin \theta_r, \\ \|\mathbf{P} - \tilde{\mathbf{P}}\|_F^2 &= 2\|\sin \boldsymbol{\Theta}\|_F^2. \end{aligned}$$

要验证第一式, 先对两组基的交叉内积作 SVD:

$$\mathbf{Q}^* \tilde{\mathbf{Q}} = \mathbf{U} \text{diag}(\cos \theta_i) \mathbf{V}^*.$$

将两边的基分别换成 $\mathbf{Q} \mathbf{U}$ 与 $\tilde{\mathbf{Q}} \mathbf{V}$, 记其第 i 列为 $\mathbf{a}_i, \mathbf{b}_i$, 就有 $\mathbf{a}_i^* \mathbf{b}_j = \cos \theta_i \delta_{i,j}$ 。这些成对方向称为主方向; 不同编号对应的张成空间彼此正交。当 $\theta_i > 0$ 时, 令 $\mathbf{c}_i = (\mathbf{b}_i - \cos \theta_i \mathbf{a}_i) / \sin \theta_i$, 则 $\mathbf{a}_i, \mathbf{c}_i$ 为该二维平面的标准正交基, 且 $\mathbf{b}_i = \cos \theta_i \mathbf{a}_i + \sin \theta_i \mathbf{c}_i$ 。在此基下, 两个秩一投影之差为

$$\begin{bmatrix} \sin^2 \theta_i & -\cos \theta_i \sin \theta_i \\ -\cos \theta_i \sin \theta_i & -\sin^2 \theta_i \end{bmatrix},$$

其特征值为 $\pm \sin \theta_i$, 而 $\mathbf{b}_i$ 在第一子空间外的分量长度为 $\sin \theta_i$ 。零角对应 $\mathbf{a}_i = \mathbf{b}_i$, 贡献为零; 两子空间之和的正交补上两个投影也都为零, 故取各块最大值即得第一式。第二式也可直接展开迹, 得到 $2r - 2\|\mathbf{Q}^* \tilde{\mathbf{Q}}\|_F^2$ 。扰动后方向落到原子空间之外的分量、两个投影的距离和主角, 因而可以相互换算。

6.6.3.1 特征值与特征方向的变化

设 $\tilde{\mathbf{A}} = \mathbf{A} + \mathbf{E}$, $\mathbf{A}, \mathbf{E}$ 均自伴, 两组特征值都降序排列。Weyl 界为

$$|\tilde{\lambda}_i - \lambda_i| \leq \|\mathbf{E}\|_2. \quad (6.85)$$

其逐指标证明直接用本章的变分原理。令 E_i 为 $\mathbf{A}$ 前 i 个特征向量的张成空间, F_i 为第 i 至 d 个特征向量的张成空间。对任意单位 $\mathbf{x}$, $|\mathbf{x}^* \mathbf{E} \mathbf{x}| \leq \|\mathbf{E}\|_2$ 。在 Courant–Fischer 的最大最小表达中取 $S = E_i$, 得 $\tilde{\lambda}_i \geq \lambda_i - \|\mathbf{E}\|_2$; 在最小最大表达中取 $T = F_i$, 得 $\tilde{\lambda}_i \leq \lambda_i + \|\mathbf{E}\|_2$ 。合并即得结论, 不要求特征值彼此不同。

若两个特征值几乎相等, 相应方向就很难区分, 小扰动可能使方向大幅旋转。所以控制方向变化还要检查目标特征值与其余特征值之间的间隔, 即谱隙。令 λ_i 为重数为 1 的单特征值, $\mathbf{q}_i, \tilde{\mathbf{q}}_i$ 为原矩阵及扰动后对应单位方向。定义实际分离量 $\text{sep}_i = \min_{j \neq i} |\tilde{\lambda}_i - \lambda_j|$ 。若 $\text{sep}_i > 0$, 一维 Davis–Kahan 残差界为

$$\sin \angle(\mathbf{q}_i, \tilde{\mathbf{q}}_i) \leq \frac{\|\mathbf{E}\|_2}{\text{sep}_i}. \quad (6.86)$$

确实, 将 $(\mathbf{A} - \tilde{\lambda}_i \mathbf{I})\tilde{\mathbf{q}}_i = -\mathbf{E}\tilde{\mathbf{q}}_i$ 投影到各 $\mathbf{q}_j$, $j \neq i$, 得 $\mathbf{q}_j^* \tilde{\mathbf{q}}_i = -\mathbf{q}_j^* \mathbf{E} \tilde{\mathbf{q}}_i / (\lambda_j - \tilde{\lambda}_i)$ 。平方求和后, 左侧正是 $\sin^2 \angle$, 右侧不超过 $\|\mathbf{E}\tilde{\mathbf{q}}_i\|_2^2 / \text{sep}_i^2$ 。若原间隙 $\delta_i = \min_{j \neq i} |\lambda_i - \lambda_j|$, 则 Weyl 界给 $\text{sep}_i \geq \delta_i - \|\mathbf{E}\|_2$ 。只有正的剩余分离量才能代入该分母; 若还要把扰动后的方向视为唯一方向, 除了符号或相位的自由, 还需确认扰动后对应的特征值也是单特征值。

二维例给出可直接计算的转角。令

$$\mathbf{A}_\gamma = \begin{bmatrix} 1+\gamma & 0 \\ 0 & 1 \end{bmatrix}, \quad \mathbf{E}_\epsilon = \begin{bmatrix} 0 & \epsilon \\ \epsilon & 0 \end{bmatrix}, \quad \gamma > 0, \epsilon > 0.$$

最大特征值增量为 $\sqrt{(\gamma/2)^2 + \epsilon^2} - \gamma/2 \leq \epsilon$ 。用旋转基消去非对角元, 得到最大特征向量与 $\mathbf{e}_1$ 的夹角

$$\theta = \frac{1}{2} \arctan(2\epsilon/\gamma) \in (0, \pi/4).$$

$\epsilon \ll \gamma$ 时 $\theta \approx \epsilon/\gamma$; 固定 ϵ 而缩小间隙时, 方向可以转动数十度, 特征值变化却始终不超过 ϵ 。图 6.9 取 $\epsilon = 0.02$ 展示两者。

若多个相邻特征值相同或很接近, 逐个辨认方向可能没有意义, 可以把它们合为一组, 称为谱簇, 改为比较整组方向张成的子空间。设 $1 \leq r < d$, $\mathbf{Q}_r, \tilde{\mathbf{Q}}_r$ 表示前 r 维特征子空间, 并有 $\text{sep}_r = \tilde{\lambda}_r - \lambda_{r+1} > 0$ 。Davis–Kahan 界在此单侧分离情形给出

$$\|\mathbf{P} - \tilde{\mathbf{P}}\|_2 \leq \frac{\|\mathbf{E}\|_2}{\text{sep}_r}.$$




图 6.9 同一对称扰动下，谱值稳定不等于方向稳定，固定 $\epsilon = 0.02$ 。左图为最大特征值增量 $\Delta\lambda_{\max} = \sqrt{(\gamma/2)^2 + 0.02^2} - \gamma/2$ ，灰虚线为扰动范数 0.02；右图为最大特征方向转角 $\theta = \frac{1}{2} \arctan(0.04/\gamma)$ ，角度用度表示。两图横轴均为原始谱隙 γ ，采用相同的对数刻度。所有数值均来自二阶特征方程的解析解。

为看清为何能控制整个块，取原补空间的正交基 $Q_\perp$ ，令 $C = Q_\perp^* \tilde{Q}_r$ ， $H = Q_\perp^* A Q_\perp$ 、 $K = \tilde{\Lambda}_r$ 、 $D = Q_\perp^* E \tilde{Q}_r$ 。投影后的特征方程为 $HC - CK = -D$ 。由于 $\lambda_{\max}(H) \leq \lambda_{r+1}$ 、 $\lambda_{\min}(K) = \tilde{\lambda}_r$ ，其解为

$$C = \int_0^\infty e^{tH} D e^{-tK} dt, \quad \|C\|_2 \leq \int_0^\infty e^{-t \text{sep}_r} \|D\|_2 dt.$$

对被积式求导可验证方程，指数衰减保证无穷端为零；结合投影距离恒等式便得到上界。原边界间隙 $\delta = \lambda_r - \lambda_{r+1}$ 给出 $\text{sep}_r \geq \delta - \|E\|_2$ 。对于中间谱簇，补谱分居两侧，应重新核对分离形式；逐元素的 Sylvester 关系仍给出按最小谱距离控制的 Frobenius 界，但不能不查条件就照搬上面的单侧谱范数常数。

簇内重数不妨碍比较整个块。例如 $\text{diag}(2, 2, 0)$ 的前二维基可任意旋转，但投影恒为 $\text{diag}(1, 1, 0)$ ； λI 中的单个方向则完全没有可辨认性。PCA 若在一组相等或接近的奇异值中间截断，边界方向同样敏感。在这些情形中，矩阵本身就没有确定唯一的单个方向；算法换了一组基，并不意味着找错了子空间。

自伴条件不可删去。若一般矩阵可对角化为 $V \Lambda V^{-1}$ ，对扰动后任一特征值 μ ，特征方程及对角逆范数给 $\min_i |\mu - \lambda_i| \leq \|V\|_2 \|V^{-1}\|_2 \|E\|_2$ (Bauer-Fike 界)。当 μ 本就是原特征值时结论直接成立；否则由 $(\Lambda - \mu I) V^{-1} w = -V^{-1} E w$ 求逆并约去 $\|w\|_2$ 即可。不可对角化时甚至可能失去这种线性尺度，例如 $\begin{bmatrix} 0 & 1 \\ 0 & 0 \end{bmatrix}$ 在左下角加入 $\epsilon > 0$ 后，两个特征值变为 $\pm\sqrt{\epsilon}$ ，大于扰动范数 ϵ 的量级。

6.6.3.2 奇异值与奇异方向的变化

一般矩形矩阵没有通常意义的特征值，前面的自伴扰动界不能直接使用。不过，可以把它的奇异值放到一个更大的自伴矩阵的特征值中，再使用已经证明的界。定义对称扩张

$$\mathcal{H}(\mathbf{A}) = \begin{bmatrix} \mathbf{0} & \mathbf{A} \\ \mathbf{A}^* & \mathbf{0} \end{bmatrix}.$$

每个正奇异三元组给出扩张矩阵的特征向量

$$\frac{1}{\sqrt{2}} \begin{bmatrix} \mathbf{u}_i \\ \mathbf{v}_i \end{bmatrix}, \quad \frac{1}{\sqrt{2}} \begin{bmatrix} \mathbf{u}_i \\ -\mathbf{v}_i \end{bmatrix},$$

对应特征值 σ_i 和 $-\sigma_i$ ，剩余方向给零。且 $\|\mathcal{H}(\mathbf{E})\|_2 = \|\mathbf{E}\|_2$ ，因为其平方为以 $\mathbf{E}\mathbf{E}^*$ 、 $\mathbf{E}^*\mathbf{E}$ 为对角块的矩阵。Weyl 界因此给出

$$|\tilde{\sigma}_i - \sigma_i| \leq \|\mathbf{E}\|_2, \quad \tilde{\mathbf{A}} = \mathbf{A} + \mathbf{E}. \quad (6.87)$$

这要求正奇异值之间有间隙。它也补齐前面的秩保持伪逆讨论：若两矩阵秩同为 $r > 0$ 且 $\|\mathbf{E}\|_2 < \sigma_r(\mathbf{A})$ ，则 $\sigma_r(\mathbf{B}) \geq \sigma_r(\mathbf{A}) - \|\mathbf{E}\|_2 > 0$ ，可在式 (6.78) 取这一共同下界。只有该不等式而没有同秩条件，仍不能排除原零奇异值变成新的微小正值。

左右方向则需要分别比较。设 $1 \leq k \leq \min(m, n)$ ， $\mathbf{U}_k, \mathbf{V}_k$ 与 $\tilde{\mathbf{U}}_k, \tilde{\mathbf{V}}_k$ 分别来自两矩阵的前 k 个奇异方向，越过列表末端的奇异值按零计，并假设 $\text{sep}_W = \tilde{\sigma}_k - \sigma_{k+1} > 0$ 。定义相对于原矩阵的两侧奇异方程残差

$$\mathbf{R} = \mathbf{A}\tilde{\mathbf{V}}_k - \tilde{\mathbf{U}}_k\tilde{\Sigma}_k, \quad \mathbf{S} = \mathbf{A}^*\tilde{\mathbf{U}}_k - \tilde{\mathbf{V}}_k\tilde{\Sigma}_k.$$

对于扰动矩阵的精确 SVD，它们分别是 $-\mathbf{E}\tilde{\mathbf{V}}_k$ 和 $-\mathbf{E}^*\tilde{\mathbf{U}}_k$ 。Wedin 正弦界的 Frobenius 版本为

$$(\|\sin \Theta(\mathbf{U}_k, \tilde{\mathbf{U}}_k)\|_F^2 + \|\sin \Theta(\mathbf{V}_k, \tilde{\mathbf{V}}_k)\|_F^2)^{1/2} \leq \frac{(\|\mathbf{R}\|_F^2 + \|\mathbf{S}\|_F^2)^{1/2}}{\text{sep}_W}. \quad (6.88)$$

为说明条件与常数，记扰动后左右方向落在原左右补空间中的分量为 $\mathbf{C} = \mathbf{U}_\perp^* \tilde{\mathbf{U}}_k$ 、 $\mathbf{D} = \mathbf{V}_\perp^* \tilde{\mathbf{V}}_k$ 。对原来未保留的一对奇异方向 $j > k$ 和目标列 $i \leq k$ ，投影残差得到

$$\begin{bmatrix} -\tilde{\sigma}_i & \sigma_j \\ \sigma_j & -\tilde{\sigma}_i \end{bmatrix} \begin{bmatrix} C_{j,i} \\ D_{j,i} \end{bmatrix} = \begin{bmatrix} (\mathbf{U}_\perp^* \mathbf{R})_{j,i} \\ (\mathbf{V}_\perp^* \mathbf{S})_{j,i} \end{bmatrix},$$

其中 j 在补空间矩阵中按相应行索引理解。该二阶块的最小奇异值为 $\tilde{\sigma}_i - \sigma_j \geq \text{sep}_W$ 。矩形多出来的未配对零方向只需除以 $\tilde{\sigma}_i$ ，也不小于同一分离量。各项平方求和，再用投影不增加 Frobenius 范数及 $\|\mathbf{C}\|_F = \|\sin \Theta_U\|_F$ ，便得到式 (6.88)⁴。

⁴ G. H. Golub, C. F. Van Loan, *Matrix Computations*, Johns Hopkins University Press, 2013, 4th ed.

因此两侧角度的总量至多为 $\sqrt{2k}\|E\|_2/\text{sep}_W$ ；保留残差形式往往比这个粗界更有信息，也能评价近似算出的奇异向量。前 k 个奇异值内部允许重复，控制整个块只需边界分离；要辨认其中一个向量，还需与两侧相邻值分离，并排除零值的自由延拓。原边界间隙 $\delta = \sigma_k - \sigma_{k+1}$ 给 $\text{sep}_W \geq \delta - \|E\|_2$ 。没有可靠边界间隙时，最优低秩误差仍可稳定，却不能把算法返回的某组压缩方向当作唯一的数据结构。PCA 与低秩近似必须分别报告误差尺度和方向可辨认性。

6.6.4 矩阵函数值的扰动与稳定性

幂、指数和平方根将一个矩阵变成另一个矩阵。矩阵输入的扰动会插入乘积的不同位置，这些位置一般不能合并。先对固定整数 $k \geq 1$ 展开，得到

$$(A + E)^k - A^k = \sum_{j=0}^{k-1} A^{k-1-j} E A^j + O(\|E\|^2).$$

例如平方的一阶项是 $AE + EA$ ，不总是 $2AE$ 。对有限扰动还有精确的望远镜恒等式

$$(A + E)^k - A^k = \sum_{j=0}^{k-1} (A + E)^{k-1-j} E A^j.$$

因此其范数不超过 $kM^{k-1}\|E\|$ ， $M = \max(\|A + E\|, \|A\|)$ 。此界对固定 k 成立，随 k 可能快速增大；单次变换接近并不保证所有迭代次数的结果都同样接近。

沿用第3章的全微分，把矩阵看成有限坐标对象。若 f 在 A 的一个开邻域中有定义，且存在对 E 线性的映射 L_f 使

$$f(A + E) - f(A) = L_f(A, E) + o(\|E\|), \quad (6.89)$$

则 L_f 称为相应Fréchet 导数 (Fréchet derivative)。讨论实自伴矩阵时，开邻域指自伴矩阵空间中的开集，不是默许任意非自伴扰动仍使用相同实谱定义。上述幂展开给出多项式函数的导数；高阶余项的常数依赖 A 和固定次数，不能在次数增大时无条件保持。

自伴谱使一般函数的一阶变化可按坐标计算。设 $A = Q \text{diag}(\lambda_i) Q^*$ ， f 在包含该谱的实开区间上连续可微。定义一阶差商矩阵

$$F_{i,j}^{[1]} = \begin{cases} \frac{f(\lambda_i) - f(\lambda_j)}{\lambda_i - \lambda_j}, & \lambda_i \neq \lambda_j, \\ f'(\lambda_i), & \lambda_i = \lambda_j. \end{cases}$$

对自伴扰动有

$$L_f(A, E) = Q(F^{[1]} \odot (Q^* E Q)) Q^*. \quad (6.90)$$

对单项式 z^k , 把上一段的各插入项写到特征坐标中, 其 (i, j) 元素的系数是 $\sum_{\ell=0}^{k-1} \lambda_i^{k-1-\ell} \lambda_j^\ell$, 不同根时等于差商, 相同根时等于 $k\lambda_i^{k-1}$, 故多项式情况已证。对一般 C^1 函数, 取多项式 p 在有限个不同谱点上同时匹配 f 和 f' 。这样的多项式为何存在, 可以用已知的维数原理说明。设不同谱点共 s 个, 将次数小于 $2s$ 的多项式映到这 s 点的函数值与一阶导数, 得到一个线性映射。若所有读数都为零, 多项式在每个谱点都有二重零点, 即能被各 $(z - \lambda_i)^2$ 的乘积整除; 次数限制使它只能为零。这个映射的定义域和值域同为 $2s$ 维, 单射便是满射, 因而可以匹配任意给定的 $2s$ 个读数, 包括 f 和 f' 在谱点上的值。余函数 $g = f - p$ 在每个谱点均有 $g = g' = 0$, 故附近 $g(\lambda_i + h) = o(|h|)$ 。由 Weyl 界, $\mathbf{A} + \mathbf{E}$ 的每个特征值距原谱不超过 $\|\mathbf{E}\|_2$, 于是 $\|g(\mathbf{A} + \mathbf{E})\|_2 = o(\|\mathbf{E}\|_2)$, 且 $g(\mathbf{A}) = 0$ 。所以多项式的导数表达也给 f 的导数, 证明余项条件。

对角项由标量导数控制, 非对角项由不同谱点的差商控制。当 $\mathbf{AE} = \mathbf{EA}$ 时, 在 $\mathbf{A}$ 的特征坐标中, $\mathbf{E}$ 不会把不同特征值对应的子空间相互混合, 可化为 $L_f = f'(\mathbf{A})\mathbf{E}$; 交换性是充分条件, 不是必要条件, 例如仿射 f 即使不交换也满足这个形式。在 Frobenius 范数下, 差商表达还直接给 $\|L_f(\mathbf{A}, \mathbf{E})\|_F \leq \max_{i,j} |f'_{i,j}| \|\mathbf{E}\|_F$, 这提供当前函数任务的局部绝对敏感性。

指数对任何方阵均有定义。令 $\mathbf{B} = \mathbf{A} + \mathbf{E}$, 对 $e^{(1-s)\mathbf{B}}e^{s\mathbf{A}}$ 关于 s 求导并积分, 得到

$$e^{\mathbf{A}+\mathbf{E}} - e^{\mathbf{A}} = \int_0^1 e^{(1-s)(\mathbf{A}+\mathbf{E})}\mathbf{E}e^{s\mathbf{A}} ds.$$

其中保留了 $\mathbf{E}$ 两侧的次序。在有界邻域内, 把第一指数中的 $\mathbf{E}$ 去掉只改变 $O(\|\mathbf{E}\|^2)$, 因此

$$L_{\exp}(\mathbf{A}, \mathbf{E}) = \int_0^1 e^{(1-s)\mathbf{A}}\mathbf{E}e^{s\mathbf{A}} ds. \quad (6.91)$$

交换时可合成 $e^{\mathbf{A}}\mathbf{E}$; 一般情形不行。例如 $\mathbf{A} = \text{diag}(0, \log 2)$, $\mathbf{E} = \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}$ 时, 导数的两个非对角元均为 $1/\log 2$, 而 $e^{\mathbf{A}}\mathbf{E}$ 的两个非对角元分别为 1 和 2。有限差的粗界为 $\|e^{\mathbf{A}+\mathbf{E}} - e^{\mathbf{A}}\| \leq e^{\max(\|\mathbf{A}+\mathbf{E}\|, \|\mathbf{A}\|)}\|\mathbf{E}\|$; 非正规结构或更具体范数可能需要更细评价。

平方根的定义域更窄。设 $\mathbf{A} > 0$, $\mathbf{S} = \mathbf{A}^{1/2} > 0$, 只考虑保持正定的自伴扰动。对 $\mathbf{S}^2 = \mathbf{A}$ 求一阶变化, $\mathbf{Z} = L_{\sqrt{\cdot}}(\mathbf{A}, \mathbf{E})$ 必须满足

$$\mathbf{SZ} + \mathbf{ZS} = \mathbf{E}.$$

这是前面定义并分析过的 Sylvester 方程, 而不是 $2\mathbf{SZ} = \mathbf{E}$ 。 $\mathbf{S}$ 的特征值 $s_i > 0$ 保证全部 $s_i + s_j > 0$, 故解唯一, 且在特征基中

$$(Q^* \mathbf{Z} Q)_{i,j} = \frac{(Q^* \mathbf{E} Q)_{i,j}}{s_i + s_j}.$$

这一表达与 $f(z) = \sqrt{z}$ 的差商完全相同, 因此确实给出微分, 而不只是必要方程。它还给 Frobenius 界 $\|\mathbf{Z}\|_F \leq \|\mathbf{E}\|_F / (2\sqrt{\lambda_{\min}(\mathbf{A})})$ 。例如 $\mathbf{A} = \text{diag}(1, 4)$, 上述非对角扰动给 $Z_{1,2} = Z_{2,1} = 1/3$; 直接写成 $\frac{1}{2}\mathbf{A}^{-1/2}\mathbf{E}$ 会得到 $1/2$ 和 $1/4$, 不仅数值错, 也失去自伴性。

若 $\mathbf{A}$ 仅半正定, 把一个零特征值改成 $\epsilon > 0$, 平方根的变化为 $\sqrt{\epsilon}$ 。变化量与扰动量之比 $\sqrt{\epsilon}/\epsilon = 1/\sqrt{\epsilon}$ 随 $\epsilon \rightarrow 0$ 无界, 不能沿用正定邻域的可微性或含 $s_i + s_j$ 的逆。可逆矩阵的微分 $D(\mathbf{A}^{-1})[\mathbf{E}] = -\mathbf{A}^{-1}\mathbf{E}\mathbf{A}^{-1}$, 以及正定域上标量函数 $D(\log \det \mathbf{A})[\mathbf{E}] = \text{tr}(\mathbf{A}^{-1}\mathbf{E})$, 回用第3章的推导; 前者的有限扰动在本章已经分析, 后者的标量输出不等于矩阵 $\log \mathbf{A}$ 的导数。

函数计算仍要评价算法, 而不止评价导数。例如程序返回自伴正定候选 $\hat{\mathbf{S}}$, 其平方根方程残差为 $\mathbf{R} = \hat{\mathbf{S}}^2 - \mathbf{A}$ 。令 $\mathbf{D} = \hat{\mathbf{S}} - \mathbf{S}$, 则精确有 $\hat{\mathbf{S}}\mathbf{D} + \mathbf{D}\mathbf{S} = \mathbf{R}$ 。正定性与 Sylvester 积分表示给出, 在谱范数或 Frobenius 范数下,

$$\|\hat{\mathbf{S}} - \mathbf{S}\| \leq \frac{\|\mathbf{R}\|}{\lambda_{\min}(\hat{\mathbf{S}}) + \sqrt{\lambda_{\min}(\mathbf{A})}}.$$

同时 $\hat{\mathbf{S}}$ 是邻近正定输入 $\mathbf{A} + \mathbf{R}$ 的精确正定平方根, 所以残差也给后向误差解释。若不检查正定分支, $\hat{\mathbf{S}} = -\mathbf{S}$ 有零残差却不是所求平方根; 若分母很小, 小残差仍可能对应较大前向误差。

幂的快速平方、指数的缩放与平方以及 Schur 形式上的函数计算都有各自的舍入传播。应把返回值与同一输入的精确函数值比较, 并检查方法声明的前向或后向界; 一个解析恒等式并不自动证明实现稳定。这也把函数计算接回本章的主线: 先确定算法应当返回哪个对象, 再判断误差来自输入还是计算, 最后用与该任务相符的残差、条件数或扰动界检验结果。

6.7 本章小结

近共线设计矩阵把本章的几种问题串联起来。对象所在的空间决定什么能够线性组合, 基决定怎样记坐标, 内积和范数决定怎样比较误差; 两列几乎同向时, 同一个输出可由两个很大的相消系数表示。坐标很大不等于对象很大, 换坐标也不等于施加了一个新变换。矩阵通过基像记录变换, 加法、复合、分块和索引缩并则组织其运算; 固定权重的线性读取不能替代对完整注意力或其他输入依赖操作的分析。

反求输入先问输出是否可达。不可达时, 投影给最近输出; 输入不唯一时, 零空间正交补再给最小范数选择, 二者共同确定伪逆。LU、QR、Cholesky 与迭代法落实这些任务, 但它们使用的结构不同。零初始化梯度迭代能选出最小范数解, 是因为更新留在行空间, 并不是所有下降算法都隐含同一种范数偏好。

反复作用要求同一个方阵。特征方向足够时，幂化成各尺度的幂；方向不足时，Jordan 幂零部分带来多项式因子。二维迭代例说明长期衰减与短时放大可以并存：谱半径控制固定矩阵的长期衰减，非正交方向间的相消影响有限步长度。指数、平方根和对数还有各自定义域，非交换微分必须保留左右作用的次序。

压缩关注的是保留多少输入输出方向。SVD 先给精确的正交配对，截断才在秩预算下给最优误差；反过来，最大尾奇异值或尾部奇异值的平方和确定误差阈值所需的最小秩。PCA 是中心化有限数据的平方重构实例，核范数惩罚会改变目标，稳定秩等辅助尺度则不能替代具体误差约束下的最优整数秩。

答案存在、表示唯一、近似最优、方向可辨认和计算可靠是不同保证。近共线性使小奇异方向在反求中放大，即使训练拟合稳定，系数与外推仍可能敏感；截断和岭收缩降低敏感性，同时舍弃或削弱信息。谱值变化小也不保证方向稳定，子空间需有相对于扰动的可靠分离。后向稳定算法只引入小的等效输入变化，能否得到小前向误差仍由问题条件决定。保留这些区别，才能在后续概率、信号和动态问题中正确使用同一套矩阵工具。第 7 章进一步研究局部坐标、切空间、度量与对称性，线性变换将在那里成为描述弯曲空间局部行为的工具。

非线性空间与流形

上一章在固定向量空间中区分了对象、坐标与线性变换。现在把可选对象限制在一个圆上：两个圆上点的平均值通常不在圆上，沿切线走有限一步也会离开圆。怎样记录位置、选择可行的变化方向，并比较两点之间的路程？这些问题不能只靠换一组基解决，因为限制来自可行集合本身。即使每个小邻域都近似平直，局部记录也未必能拼成一组全局坐标。

为了进一步区分真实的可行方向与观测误差，我们把圆弧附近的一条窄带作为贯穿例子。若点可以沿带的长度和宽度两个方向移动，就有两个自由度；若点只能落在中心线上，就只有一个自由度。测量误差可能使观测点偏离中心线，但不因此增加真实位置的自由度。只有一组观测点时，还要先问这些点间的距离能确定什么、旋转或重编号后应保留什么，以及把邻近点连起来能反映怎样的整体形状。下面先讨论这些表示问题，再在明确的连续模型上计算方向、长度与运动。

用光滑流形描述连续空间以后，我们可以在每个点附近作线性近似，找出允许的瞬时速度。但方向本身还没有长度，需要度量来规定长度，再沿路径累计得到路程。若要判断沿路是否转弯，还需要比较不同位置的方向，这会引出平行移动与曲率。这些工具也用于优化：例如，在曲面上找一个损失最小的位置，和调整曲面各处的函数值使它们更平滑，就需要不同的优化方向。以下使用基础分析、线性代数和前文的优化知识；仅有有限点间距离或组合邻接关系时，还不能假定对象是光滑流形。

7.1 非线性空间的表示

7.1.1 距离信息下的坐标表示

设只知道 n 个点之间的距离，能否给它们安排欧氏坐标，并精确保留这些距离？先从反方向计算。将 $\mathbf{y}_1, \dots, \mathbf{y}_n \in \mathbb{R}^d$ 按行组成 $\mathbf{Y} \in \mathbb{R}^{n \times d}$ 。定义 6.6 中的 Gram 矩阵 $\mathbf{B} = \mathbf{Y}\mathbf{Y}^\top$ 记录两两内积，平方距离则为

$$\delta_{i,j} = \|\mathbf{y}_i - \mathbf{y}_j\|_2^2 = b_{i,i} + b_{j,j} - 2b_{i,j}. \quad (7.1)$$

距离不记录原点：将全部点平移同一个向量，差向量不变，内积却会改变。因此从距离恢复内积前，需要先固定平移自由度。

把点云均值选为原点。令 $\mathbf{1} \in \mathbb{R}^n$ 为全一向量，定义

$$\mathbf{J} = \mathbf{I}_n - \frac{1}{n} \mathbf{1} \mathbf{1}^\top. \quad (7.2)$$

它满足 $\mathbf{J}^\top = \mathbf{J}$ 、 $\mathbf{J}^2 = \mathbf{J}$ 和 $\mathbf{J}\mathbf{1} = \mathbf{0}$ ； $\mathbf{J}\mathbf{Y}$ 从每行减去样本均值。若 $\Delta = [\delta_{i,j}]$ ，式 (7.1) 写成

$$\Delta = \text{diag}(\mathbf{B})\mathbf{1}^\top + \mathbf{1} \text{diag}(\mathbf{B})^\top - 2\mathbf{B}.$$

左右各乘 $\mathbf{J}$ ，前两项消失。对于已中心化的坐标， $\mathbf{J}\mathbf{Y} = \mathbf{Y}$ ，于是

$$\mathbf{B} = -\frac{1}{2} \mathbf{J} \Delta \mathbf{J}. \quad (7.3)$$

这称为双重中心化 (double centering)：左右乘 $\mathbf{J}$ 分别处理矩阵的两个点索引，消去均值项，得到以点云中心为原点的内积。这里仅固定了原点，尚未压缩坐标维数。

任何真实坐标产生的 Gram 矩阵都半正定，因为 $\mathbf{c}^\top \mathbf{B} \mathbf{c} = \|\mathbf{Y}^\top \mathbf{c}\|_2^2 \geq 0$ 。半正定性因此是必要条件。要证明它也足以重构距离，还须确认双重中心化不会把两份不同的平方距离矩阵变成同一个 Gram 矩阵。下面的引理解决这个问题。

引理 7.1 双重中心化核的形式 若对称矩阵 $\mathbf{H} \in \mathbb{R}^{n \times n}$ 满足 $\mathbf{J} \mathbf{H} \mathbf{J} = \mathbf{0}$ ，则存在 $\mathbf{a} \in \mathbb{R}^n$ 使 $\mathbf{H} = \mathbf{1} \mathbf{a}^\top + \mathbf{a} \mathbf{1}^\top$ 。若另有 $h_{i,i} = 0$ 对全部 i 成立，则 $\mathbf{H} = \mathbf{0}$ 。

证明. 令 $\mathbf{m} = \mathbf{H}\mathbf{1}/n$ 、 $\mu = \mathbf{1}^\top \mathbf{H}\mathbf{1}/n^2$ 。展开假设得到

$$\mathbf{H} = \mathbf{1} \mathbf{m}^\top + \mathbf{m} \mathbf{1}^\top - \mu \mathbf{1} \mathbf{1}^\top.$$

取 $\mathbf{a} = \mathbf{m} - (\mu/2)\mathbf{1}$ 即得所需形式。其对角元为 $h_{i,i} = 2a_i$ ，故零对角条件迫使每个 $a_i = 0$ ，进而 $\mathbf{H} = \mathbf{0}$ 。 ■

定理 7.2 有限距离的欧氏坐标重构 设 $\Delta \in \mathbb{R}^{n \times n}$ 对称且对角元为零，并令 $\mathbf{B} = -\mathbf{J} \Delta \mathbf{J}/2$ 。矩阵 Δ 是某组欧氏点的平方距离矩阵，当且仅当 $\mathbf{B}$ 半正定。精确保留全部距离所需的最小欧氏维数为 $r = \text{rank}(\mathbf{B})$ 。

证明. 若已有欧氏点，先中心化，式 (7.3) 便给出 $\mathbf{B} = \mathbf{Y} \mathbf{Y}^\top$ ，所以 $\mathbf{B}$ 半正定。

反过来, 半正定性和谱定理给出紧谱分解 $\mathbf{B} = \mathbf{Q}_r \mathbf{\Lambda}_r \mathbf{Q}_r^\top$, 其中 $\mathbf{\Lambda}_r$ 含 r 个正特征值。取

$$\mathbf{Y} = \mathbf{Q}_r \mathbf{\Lambda}_r^{1/2}, \quad (7.4)$$

则 $\mathbf{Y} \mathbf{Y}^\top = \mathbf{B}$ 。又因 $\mathbf{B} \mathbf{1} = \mathbf{0}$, $\|\mathbf{Y}^\top \mathbf{1}\|_2^2 = \mathbf{1}^\top \mathbf{B} \mathbf{1} = 0$, 坐标已中心化。用式 (7.1) 从 $\mathbf{B}$ 生成 $\mathbf{\Delta}'$ 。 $\mathbf{\Delta}'$ 与 $\mathbf{\Delta}$ 的双重中心化均为 $\mathbf{B}$, 两者之差对称、对角为零且双重中心化为零。前一引理遂给出 $\mathbf{\Delta}' = \mathbf{\Delta}$ 。

任意 $\mathbb{R}^k$ 中的坐标矩阵所产生的 Gram 矩阵秩至多为 k , 因此精确重构要求 $k \geq r$; 上述构造又在 $k = r$ 时达到要求。 $r = 0$ 时全部点重合, 可视作嵌入零维空间。 ■

经典尺度分析用这个判据从距离重构坐标。若 $\mathbf{B}$ 出现负特征值, 就没有一组欧氏点能精确保留输入的全部距离。逐对测量距离时, 每次测量各有误差, 组合起来的读数可能无法由同一组欧氏点实现, 于是出现负特征值。若先得到一组带噪坐标, 再由这些坐标精确计算距离, 距离仍来自一组欧氏点, 其 Gram 矩阵仍半正定。不过, 这时重构的是观测位置, 不能由此恢复误差发生前的真实位置。

距离保留了相对位置, 却不能确定绝对位置和朝向, 也不能区分一组点与它的镜像。对正交矩阵 $\mathbf{Q} \in \mathbb{R}^{r \times r}$ 和平移 $\mathbf{a}$, 令 $\tilde{\mathbf{y}}_i = \mathbf{Q} \mathbf{y}_i + \mathbf{a}$, 则

$$\|\tilde{\mathbf{y}}_i - \tilde{\mathbf{y}}_j\|_2 = \|\mathbf{Q}(\mathbf{y}_i - \mathbf{y}_j)\|_2 = \|\mathbf{y}_i - \mathbf{y}_j\|_2.$$

正交变换既含旋转, 也含反射。中心化只消去平移, 不能选择唯一朝向。

对于中心化的最小维坐标, 这也是全部不确定性。设 $\mathbf{Y}, \tilde{\mathbf{Y}} \in \mathbb{R}^{n \times r}$ 均列满秩并产生相同距离, 则双重中心化给出相同 $\mathbf{B}$ 。它们的列空间都等于 $\mathbf{B}$ 的值域。对 $\mathbf{B} = \mathbf{Q}_r \mathbf{\Lambda}_r \mathbf{Q}_r^\top$ 定义 $\mathbf{M} = \mathbf{\Lambda}_r^{-1/2} \mathbf{Q}_r^\top \mathbf{Y}$, 可得

$$\mathbf{Y} = \mathbf{Q}_r \mathbf{\Lambda}_r^{1/2} \mathbf{M}, \quad \mathbf{M} \mathbf{M}^\top = \mathbf{\Lambda}_r^{-1/2} \mathbf{Q}_r^\top \mathbf{B} \mathbf{Q}_r \mathbf{\Lambda}_r^{-1/2} = \mathbf{I}_r.$$

方阵 $\mathbf{M}$ 因而正交。写 $\mathbf{M} = \mathbf{U}^\top$, 对另一组坐标同样得到 $\tilde{\mathbf{Y}} = \mathbf{Q}_r \mathbf{\Lambda}_r^{1/2} \tilde{\mathbf{U}}^\top$, 于是 $\tilde{\mathbf{Y}} = \mathbf{Y} \mathbf{U} \tilde{\mathbf{U}}^\top$ 。若有重复特征值, 对应子空间中的坐标轴还可以任意旋转。即使把点放进更高维空间, 它们仍只占据一个 r 维的仿射子空间; 中心化后, 两组点在各自张成空间之间仍可由正交变换对应。

示例 7.3 三个点能否放在一条直线上 取 $\mathbf{y}_1 = (-1, 0)^\top$ 、 $\mathbf{y}_2 = (0, 1)^\top$ 、 $\mathbf{y}_3 = (1, 0)^\top$, 其均值是 $(0, 1/3)^\top$ 。平方距离与中心化结果为

$$\mathbf{\Delta} = \begin{bmatrix} 0 & 2 & 4 \\ 2 & 0 & 2 \\ 4 & 2 & 0 \end{bmatrix},$$

$$-\frac{1}{2}\mathbf{J}\Delta\mathbf{J} = \begin{bmatrix} 10/9 & -2/9 & -8/9 \\ -2/9 & 4/9 & -2/9 \\ -8/9 & -2/9 & 10/9 \end{bmatrix}. \quad (7.5)$$

正特征值为 2 和 2/3，所以精确重构需要二维。若只保留特征值 2 对应的水平方向，端点间距离仍为 2，顶点到两端的距离却从 $\sqrt{2}$ 变成 1；这是一种近似，不是另一份精确坐标。

若只能使用少于 r 个坐标，就必须允许一部分信息损失。但要先明确损失什么：两两内积、原坐标，还是两点之间的距离？即使都采用谱截断，这些目标的误差也不同。若 $\mathbf{B}$ 半正定，保留最大 $k < r$ 个特征值时，定理 6.27 保证 Gram 矩阵的 Frobenius 误差最小，平方误差为 $\sum_{j>k} \lambda_j^2$ 。在一组给定中心化坐标上作对应 PCA 投影，坐标平方重构误差则为 $\sum_{j>k} \lambda_j$ 。若原距离为 $d_{i,j} = \sqrt{\delta_{i,j}}$ ，近似坐标为 $\tilde{\mathbf{y}}_i$ ，还可以直接比较逐对距离，例如把距离应力（distance stress）取为

$$\sum_{i<j} (\|\tilde{\mathbf{y}}_i - \tilde{\mathbf{y}}_j\|_2 - d_{i,j})^2.$$

这个目标直接比较点对的距离；前两种目标分别比较 Gram 矩阵的元素与每个点的坐标。所以，Gram 矩阵或坐标重构最优，并不自动意味着逐对距离误差也最小。最大相对距离误差则比较

$$\max_{\substack{i<j \\ d_{i,j}>0}} \frac{|\|\tilde{\mathbf{y}}_i - \tilde{\mathbf{y}}_j\|_2 - d_{i,j}|}{d_{i,j}}.$$

全体点重合时不使用这个比值准则。对含负谱的 $\mathbf{B}$ ，保留最大的至多 k 个正特征值给出半正定秩至多 k 约束下的 Frobenius 近似；舍弃负谱的大小仍须与测量误差比较。

有限坐标重构也不证明潜在集合是一张光滑曲面。即使点落在圆上，输入欧氏距离记录的仍是弦长，不能把保弦长的坐标自动解释为沿圆排列的一维坐标。要表达连续对象的自由度，必须另行给出局部模型。

7.1.2 局部坐标下的流形表示

在圆的一小段上，一个角度便能定位一个点；绕完整圆却必然遇到角度断点或重复表示。流形（manifold）把这两件事分开：它要求每个点附近像某个欧氏开集，并不要求整个对象是一张欧氏坐标表。本章先讨论欧氏空间中的光滑嵌入流形。这里“光滑”指各阶导数连续；“微分同胚”指两个集合之间的双射，且这个映射与其逆都光滑¹。

定义 7.4 光滑嵌入流形 设 $0 \leq d \leq D$ 。集合 $\mathcal{M} \subseteq \mathbb{R}^D$ 称为 d 维光滑嵌入流形, 若每个 $p \in \mathcal{M}$ 都有包含它的环境开集 O 和欧氏开集之间的微分同胚 $\Psi: O \rightarrow \Psi(O) \subseteq \mathbb{R}^D$, 满足

$$\Psi(\mathcal{M} \cap O) = \Psi(O) \cap (\mathbb{R}^d \times \{\mathbf{0}_{D-d}\}).$$

这个条件要求: 在每个点附近, 都能用欧氏空间中的光滑坐标变换, 把对象变成一个 d 维的平直片段。变换后的前 d 个坐标可以自由变化, 其余坐标固定为零。因而 d 描述局部自由度, D 描述容纳对象的环境维数。定义只用了欧氏空间中已知的光滑映射, 没有预先假定流形上的光滑性。

令 $U = \{\mathbf{z} : (\mathbf{z}, \mathbf{0}_{D-d}) \in \Psi(O)\}$, 则 $\varphi(\mathbf{z}) = \Psi^{-1}(\mathbf{z}, \mathbf{0}_{D-d})$ 从开集 $U \subseteq \mathbb{R}^d$ 参数化 $\mathcal{M} \cap O$, 且 Jacobian 满列秩。要把参数真正用作坐标, 还必须能从像中的每个点唯一、连续地读回参数; Jacobian 满秩只控制局部变化, 不能单独排除绕回或自交。参数化从坐标生成点, 坐标图则反过来从点读出坐标。

定义 7.5 局部坐标图与坐标过渡 上述参数化的逆 $\chi = \varphi^{-1} : \mathcal{M} \cap O \rightarrow U$ 称为坐标图 (chart)。两张图的覆盖区域相交时, $\chi_2 \circ \chi_1^{-1}$ 把第一组坐标换成第二组坐标, 称为坐标过渡 (coordinate transition), 定义在交集的第一组坐标像上。

同一个点在重叠区域里可以有两组坐标。坐标过渡及其逆都光滑, 保证从一组坐标换到另一组坐标时, 不会破坏对连续变化和导数的描述。覆盖整个流形的一组坐标图称为图册 (atlas); “局部像 $\mathbb{R}^d$ ” 指有这种局部记录方式, 不是说流形在环境中必须平直。

单位圆的参数化 $\varphi(\theta) = (\cos \theta, \sin \theta)^\top$ 限制到 $(-\pi, \pi)$ 时漏掉 $(-1, 0)^\top$, 限制到 $(0, 2\pi)$ 时漏掉 $(1, 0)^\top$ 。两张图合起来覆盖圆, 交叠处的过渡是 θ 或 $\theta + 2\pi$ 。断点移动的是坐标, 不是圆被切断了。连续双射且逆映射也连续, 称为同胚 (homeomorphism); 它保留连续性关系, 微分同胚还要求两个方向都光滑。完整圆是紧集, 它在连续映射下的像仍紧; 非空的一维欧氏开集却不紧, 所以圆不可能与这种开集同胚, 也不能靠一张无重复的实数坐标图覆盖。它局部一维, 却至少需要二维环境才能无自交地全局嵌入; 局部维数、环境维数与最小全局嵌入维数由不同条件决定。

贯穿本章的弯曲点带取为

$$\Phi(s, u) = \begin{bmatrix} (R+u) \cos(s/R) \\ (R+u) \sin(s/R) \end{bmatrix}, \quad s \in I, \quad |u| < w < R, \quad (7.6)$$

其中 $R > 0$, $I = (s_-, s_+)$ 的长度小于 $2\pi R$, 防止绕回后重复。 s 沿中心线定位, u 记录横向偏移。定义

$$\mathcal{M}_{\text{strip}} = \{\Phi(s, u) : s \in I, |u| < w\}, \quad \mathcal{C} = \{\Phi(s, 0) : s \in I\}.$$

前者是二维开带, 后者是一维中心线; 开带与开矩形同胚, 二者均不包括端点。后面将对 Φ 求导, 检查这两个参数是否确实给出两个独立的局部方向。

从这个连续模型采样时, 潜在点 (latent point) $\mathbf{p}_i = \Phi(s_i, u_i)$ 指误差发生前的真实位置, $\mathbf{x}_i = \mathbf{p}_i + \boldsymbol{\epsilon}_i$ 才是观测。二维开带是 $\mathbb{R}^2$ 的开集, 内部点受足够小的扰动后仍在带内, 但位置已经改变; 扰动更大时, 观测也可能落到带外。若选择的潜在对象是一维中心线, 就要求 $u_i = 0$, 把横向偏离归入观测误差。此时观测一般会偏离中心线, 这部分偏离属于测量误差, 而不是第二个可行的位置坐标。仅凭有限点云看起来很窄, 仍无法决定真实对象是一维中心线, 还是横向范围很小的二维带。

7.1.3 对称变换下的表示选择

坐标可改变, 不意味着任务输出必须不变。整体旋转点带时, 长度不变, 表示朝向的向量却应同步旋转; 重排点记录的行, 则只改变编号而不移动空间中的点。要准确规定这些要求, 先明确允许哪些变换、如何复合, 再指定它们作用于什么对象。

定义 7.6 群 群 (group) G 是带有二元运算的集合。运算封闭且满足结合律, 存在恒等元 e , 每个 $g \in G$ 都存在逆元 g^{-1} 。

群描述可以依次施加、也可以撤销的变换规则。例如, 把若干数据增强操作列在一起, 并不就得到一个群: 两个操作复合后可能不在列表中, 裁剪还可能丢失信息而无法撤销。群的抽象乘法与对象上的实际操作, 通过群作用联系。

定义 7.7 群作用 群作用 (group action) 是映射 $G \times \mathcal{X} \rightarrow \mathcal{X}$, 记 $(g, x) \mapsto g \cdot x$, 满足

$$e \cdot x = x, \quad (g_1 g_2) \cdot x = g_1 \cdot (g_2 \cdot x) \quad (7.7)$$

对所有 $x \in \mathcal{X}$ 和 $g_1, g_2 \in G$ 成立。

第二条把群乘法解释为先做 g_2 、再做 g_1 。同一个群可以作用在不同空间上, 具体作用必须给出; 讨论光滑流形上的作用时, 还要另行要求相应映射光滑。

当对象是向量且作用保持线性组合时，可以直接用线性代数描述响应。

定义 7.8 线性表示 线性表示 (linear representation) 是映射 $\rho : G \rightarrow \text{GL}(V)$, 满足

$$\rho(e) = I, \quad \rho(g_1 g_2) = \rho(g_1) \rho(g_2), \quad (7.8)$$

其中 $\text{GL}(V)$ 是向量空间 V 上全部可逆线性算子组成的群。

它用线性算子实现群的复合规则。输入与输出可以取不同表示: 输入平面坐标按旋转矩阵变换, 标量输出可以取 $\rho(g) = 1$, 方向向量输出则可取同一旋转矩阵。

平面旋转群 $\text{SO}(2)$ 由行列式为 1 的二维正交矩阵组成。角度 θ 对应

$$R(\theta) = \begin{bmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{bmatrix}, \quad R(\theta_1)R(\theta_2) = R(\theta_1 + \theta_2). \quad (7.9)$$

同一旋转可作用于一个点、整组点, 或通过改变自变量作用于图像函数。这些输入空间不同。在固定环境坐标中旋转整条点带, 各点的位置变成 $R(\theta)\Phi(s, u)$ 。仍可用原来的 (s, u) 标记旋转前后相互对应的点; 环境中的位置改变了, 内部参数却不必要重新编号。

有限集合 $\{1, \dots, n\}$ 的全部置换组成对称群 S_n 。约定置换矩阵满足 $(P_\pi X)_{i,:} = X_{\pi^{-1}(i),:}$, 则 $P_{\pi_1 \pi_2} = P_{\pi_1} P_{\pi_2}$ 。对点云 $X \in \mathbb{R}^{n \times D}$, 行置换改变记录顺序, 而旋转作用在坐标列上, 写为 XR^T 。因此, 左乘置换矩阵只改变样本编号, 右乘旋转矩阵的转置则改变各点的空间位置。虽然都用矩阵乘法表示, 两个操作改变的是不同的索引。

如果任务确实要忽略某类变换, 就应把该变换关联的输入视为等价。轨道 (orbit) $G \cdot x = \{g \cdot x : g \in G\}$ 收集从 x 出发能够得到的所有输入。约定 $x \sim y$ 当且仅当存在 $g \in G$ 使 $y = g \cdot x$ 。这是等价关系: 恒等元保证反身, 逆元保证对称, 复合保证传递。轨道的集合称为轨道商 $\mathcal{X}/G$ 。这时才有明确依据说两个不同记录代表同一个等价输入。

定义 7.9 不变映射 群 G 作用于 $\mathcal{X}$ 。映射 $f : \mathcal{X} \rightarrow \mathcal{Y}$ 若满足

$$f(g \cdot x) = f(x) \quad (g \in G, x \in \mathcal{X}), \quad (7.10)$$

称为对该作用不变 (invariant)。

不变映射在同一轨道上取相同值, 因此可写成 $f = \tilde{f} \circ \pi$, 其中 $\pi(x) = G \cdot x$ 是商映射。令 $\tilde{f}(G \cdot x) = f(x)$ 之所以不依赖代表元, 正是由不变性保证。

不变性只要求同一轨道的输入得到相同输出； f 还可能把不同轨道也映到同一值，所以不能据此认定输出已保留区分不同轨道的全部信息。

轨道商在这里只是等价类集合。即使原空间光滑，也不能直接宣布商仍是同维或更低维的光滑流形。例如 $SO(2)$ 作用于 $\mathbb{R}^2$ ，轨道按半径标记，商可识别为 $[0, \infty)$ ：原点的轨道只有一个点，其余轨道是圆。商的端点不满足无边界一维流形的局部开区间条件。若讨论一般商的光滑结构，需要补充作用的正则性条件，不能仅凭“去掉一个旋转自由度”作维数相减。

当输出必须保留位置或朝向时，合理要求是让它按约定同步变化。

定义 7.10 等变映射 若 G 还作用于 $\mathcal{Y}$ ，把输出作用记为 $\rho(g)$ ，映射 $F : \mathcal{X} \rightarrow \mathcal{Y}$ 满足

$$F(g \cdot x) = \rho(g)F(x) \quad (g \in G, x \in \mathcal{X}), \quad (7.11)$$

则称为等变 (equivariant)。输出作用不必线性；当 $\mathcal{Y}$ 是向量空间且 ρ 为线性表示时，右端才是相应线性算子的作用。

例如预测点带朝向时，输入旋转后，输出向量也应旋转。标量类别、位置坐标和分割掩码所需的响应不同，应当让输出忽略变换，还是跟着变换，取决于任务需要保留什么。等变映射之后接不变汇总可得到不变输出；反过来，已丢弃朝向的信息通常不能恢复。

在点云上，对每行使用同一个映射 ϕ ，令 $F(\mathbf{X})_{i,:} = \phi(\mathbf{X}_{i,:})$ ，则第 i 行直接给出

$$F(\mathbf{P}_\pi \mathbf{X})_{i,:} = \phi(\mathbf{X}_{\pi^{-1}(i),:}) = (\mathbf{P}_\pi F(\mathbf{X}))_{i,:}.$$

所以逐点共享映射对行置换等变。再对行求和， $f(\mathbf{X}) = \sum_i \phi(\mathbf{X}_{i,:})$ ，重编号只改变求和次序，因而不变。这证明了响应关系，尚未证明求和表示能够区分任务需要的全部点集。

平移作用的例子需要同时规定定义域。对全空间上的可积函数 $k, f \in L^1(\mathbb{R}^d)$ ，令 $(T_{\mathbf{a}}f)(\mathbf{x}) = f(\mathbf{x} - \mathbf{a})$ ，卷积是将一个函数平移后与另一个相乘并积分：

$$(k * (T_{\mathbf{a}}f))(\mathbf{x}) = \int_{\mathbb{R}^d} k(\mathbf{x} - \mathbf{y})f(\mathbf{y} - \mathbf{a})d\mathbf{y} \quad (7.12)$$

$$= \int_{\mathbb{R}^d} k(\mathbf{x} - \mathbf{a} - \mathbf{z})f(\mathbf{z})d\mathbf{z} = (T_{\mathbf{a}}(k * f))(\mathbf{x}). \quad (7.13)$$

变量替换 $\mathbf{z} = \mathbf{y} - \mathbf{a}$ 说明卷积与平移可交换。 L^1 条件使等式几乎处处成立；若积分处处绝对收敛，例如一个函数连续有界、另一个可积，就可以逐点理解。有限图像的零填充、裁剪和下采样可能破坏所声称的平移等变性；循环平移配周期边界和只比较有效区域又是另外的作用，须逐项核对。

输入作用	不变输出	等变输出及其作用
平面旋转 $\mathbf{x} \mapsto \mathbf{R}\mathbf{x}$	$\ \mathbf{x}\ _2$	$F(\mathbf{x}) = \mathbf{x}$, 输出也乘 $\mathbf{R}$
点记录行置换 $\mathbf{X} \mapsto \mathbf{P}\mathbf{X}$	逐行映射后求和	逐行共享映射, 输出行也乘 $\mathbf{P}$
全空间信号平移	可积函数的全空间积分	与固定可积核卷积, 输出信号同样平移

表 7.1 先指定输入与输出作用, 才能判断不变或等变。全空间信号的恒等式不自动适用于有裁剪、边界填充或下采样的有限窗口; 结构响应也不保证表示保留了任务所需的全部信息。

表 7.1 把同一个输入作用的两种输出要求并列, 区别在于输出应该忽略变换, 还是记录变换后的对象。

若缺少直接的不变构造, 有限群平均提供了一种可检验的办法。

定理 7.11 有限群平均的不变性 对有限群 G 及任意实函数 $h : \mathcal{X} \rightarrow \mathbb{R}$, 定义

$$\bar{h}(\mathbf{x}) = \frac{1}{|G|} \sum_{g \in G} h(g \cdot \mathbf{x}). \quad (7.14)$$

则 $\bar{h}$ 对给定作用不变。

证明. 固定 $a \in G$, 由作用的复合条件,

$$\bar{h}(a \cdot \mathbf{x}) = \frac{1}{|G|} \sum_{g \in G} h((ga) \cdot \mathbf{x}).$$

映射 $g \mapsto ga$ 是 G 上的双射, 其逆为 $g \mapsto ga^{-1}$ 。更换求和索引后右端等于 $\bar{h}(\mathbf{x})$, 结论对任意 $a, \mathbf{x}$ 成立。■

连续旋转也能平均。对连续实函数 h , 二维旋转群 $\text{SO}(2)$ 给出

$$\bar{h}(\mathbf{x}) = \frac{1}{2\pi} \int_0^{2\pi} h(\mathbf{R}(\theta)\mathbf{x}) d\theta.$$

把输入先旋转 β , 被积函数变成 $h(\mathbf{R}(\theta + \beta)\mathbf{x})$ 。角度换元只移动积分区间, 而函数以 2π 为周期, 所以平均值不变。这里的均匀角度权重, 是有限群中每个元素权重相同的连续版本。

更一般的推广使用拓扑群, 即群乘法和取逆都是连续映射的群。紧拓扑群上的归一化 Haar 测度 (Haar measure) 是对左右群平移都不变的概率测度; 对可积的 $g \mapsto h(g \cdot \mathbf{x})$, 这种不变性允许作与上面相同的换元。本章不展开一般 Haar 测度的存在性证明。紧致性在这里有实质作用: 若想对实轴上全部平移赋予同样权重, 各区间 $[k, k+1)$ 就必须质量相同; 质量为正会使总量无穷, 质量为零则使全轴质量为零, 均不可能得到概率测度。

平均的代价是信息丢失。例如对 $\{\mathbf{I}, -\mathbf{I}\}$ 作用取 $h(\mathbf{x}) = x_1$, 平均恒为零; 它不仅忽略符号, 也失去幅度信息。若任务要预测朝向, 旋转平均后的标

量更无法承担原来的输出职责。有限数据增强只鼓励训练样本上的近似关系，若网络结构本身满足相应恒等式，响应关系就在指定变换和精确算术下成立。实际计算中的网格插值、边界处理及数值误差仍须另行检查。

序列中的打分也可能只需要两个位置的差 $t - s$ ，而不需要它们各自的编号。旋转的复合规则提供了一种实现这种相对位置关系的办法。对实数位置 t 和频率 ω ，令 $\mathbf{R}_\omega(t) = \mathbf{R}(\omega t)$ 。同时平移位置 s, t 不改变 $t - s$ ，而旋转复合给出

$$\mathbf{R}_\omega(s)^\top \mathbf{R}_\omega(t) = \mathbf{R}_\omega(t - s). \quad (7.15)$$

所以对固定二维向量 $\mathbf{q}, \mathbf{k}$,

$$(\mathbf{R}_\omega(s)\mathbf{q})^\top (\mathbf{R}_\omega(t)\mathbf{k}) = \mathbf{q}^\top \mathbf{R}_\omega(t - s)\mathbf{k}. \quad (7.16)$$

把多个频率对应的二维块拼在一起，仍保留这一恒等式：由位置引入的旋转因子只依赖 $t - s$ ，而不分别依赖 s 与 t 。这不意味着整个注意力网络只依赖相对位置： $\mathbf{q}, \mathbf{k}$ 的生成、其他位置特征、偏置、窗口与边界仍可能含绝对位置信息。单个非零频率块的周期为 $2\pi/|\omega|$ ，多频率组合的可区分范围需连同频率、数值精度和序列长度分析，不能据此承诺无限长度无碰撞。这里的旋转由位置编号直接决定。后面要比较曲面上不同位置的方向时，还须指定沿哪条路径、按什么规则搬运；那是另一个问题，不能只靠这个相对位置公式解决。

7.1.4 邻域关系下的拓扑表示

两条互不相交的开圆弧和一条完整圆，每个点附近都像一维开区间，整体却分别有两个连通分支和一个不可在圆内缩到点的环。拓扑 (topology) 在这里研究连续连接与孔洞等结构，不要求保持长度和角度。把开点带连续拉直，点之间原有的连接关系仍可保留；若把两端粘合，就新增了绕行一圈的路径，整体结构随之改变。局部自由度不能回答这种整体问题。

仅看有限个欧氏点，每个点都能被一个足够小的邻域单独隔开；这种离散拓扑本身不能告诉我们点来自一条曲线还是一个曲面。要由样本推测连续形状，必须另定邻域连接规则。即使已经把相邻点连成边，三条边围出的区域是否也属于对象，仍需单独指定。为使 $k + 1$ 个顶点确实张成 k 维形状，要求以一个顶点 $\mathbf{v}_0$ 为基点时，差向量 $\mathbf{v}_1 - \mathbf{v}_0, \dots, \mathbf{v}_k - \mathbf{v}_0$ 线性无关；这称为顶点的仿射独立 (affine independence)，三个顶点时就是不共线。 k 维单纯形 (simplex) 在几何上是这些顶点的凸包，在组合表示中只记录顶点集合。点、线段、填充三角形分别是零、一、二维单纯形。仿射独立保证几何维数；组合形式则用于指定哪些高阶面存在。

定义 7.12 抽象单纯复形 有限顶点集上的抽象单纯复形 (abstract simplicial complex) $\mathcal{K}$ 是一族非空顶点子集, 满足向下封闭:

$$\sigma \in \mathcal{K}, \quad \emptyset \neq \tau \subseteq \sigma \implies \tau \in \mathcal{K}. \quad (7.17)$$

含 $k+1$ 个顶点的元素称为 k 维单纯形。

加入三角面必须连同它的三条边和三个顶点一起加入, 反之不成立。这使复形能够区分“围出一圈”和“这一圈已由一个面填充”。

固定同一组点和尺度, 可以按共同覆盖或成对接近构造复形。

定义 7.13 Čech 复形与 Vietoris-Rips 复形 给定欧氏点集 $\{\mathbf{x}_i\}$ 及 $\varepsilon > 0$, 以 $B(\mathbf{x}_i, \varepsilon/2)$ 表示开球。Čech 复形 (Čech complex) $\mathcal{C}_\varepsilon$ 纳入所有满足 $\bigcap_{i \in \sigma} B(\mathbf{x}_i, \varepsilon/2) \neq \emptyset$ 的非空顶点集 σ 。Vietoris-Rips 复形 (Vietoris-Rips complex) $\mathcal{R}_\varepsilon$ 纳入所有满足 $\|\mathbf{x}_i - \mathbf{x}_j\|_2 \leq \varepsilon$ 对任意 $i, j \in \sigma$ 成立的非空顶点集。

这两种规则都向下封闭。Čech 边要求距离严格小于 ε , Rips 边在此采用不超过 ε 的约定; 开闭边界的差异须在临界尺度明确保留。更本质的差别出现在三点以上: 成对相交不保证共同交集。

例如 $\varepsilon = 1$ 、边长 0.9 的正三角形, 三对半径 0.5 的球均相交, 因此 Rips 加入三角面。覆盖三个顶点的最小球半径却是 $0.9/\sqrt{3} > 0.5$, 不存在三个球的共同交点, Čech 只保留三条边。图 7.1 中的中心叉号给出这个最小覆盖半径, 不是利用开闭球的等号差异制造反例。

尺度变化后仍可给出明确包含关系。对任意 $\eta > 0$, 有

$$\mathcal{C}_\varepsilon \subseteq \mathcal{R}_\varepsilon \subseteq \mathcal{C}_{2\varepsilon+\eta}.$$

第一个包含关系由共同交点和三角不等式推出。对第二个, 任选一个顶点作候选共同交点, 它到其余顶点的距离至多 ε , 严格小于新球半径 $\varepsilon + \eta/2$ 。若全部球改用闭球, 在相应定义下可取尺度常数 2 而不加 η 。这些是足够的普适常数, 不声称最紧; 同一尺度的复形仍不能互换。

复形何时能代表球并集的拓扑, 还依赖覆盖条件。良好覆盖 (good cover) 要求每个非空有限交集都可连续收缩到一点; 有限欧氏开球的交集为凸集, 满足这项要求。神经引理 (nerve lemma) 在该条件下说明 Čech 复形与球并集同伦等价, 即二者存在相互映射, 来回复合可以连续变形到恒等映射。这里不要求两映射互为逆, 所以比同胚弱: 闭区间可连续收缩到一个点, 与单点空间同伦等价, 却不可能与它存在双射。这个结论不等于球并集已经恢复了未知潜在流形; 后者还需要采样覆盖和尺度条件。




图 7.1 固定同组三点比较共同交集与成对条件。正三角形边长 0.9, $\varepsilon = 1$, 蓝色开球半径 0.5; 红色边满足两种构造的连边条件。三球无共同交点, Čech 不含二维面, Rips 含二维面。中心到各顶点的距离为 $0.9/\sqrt{3} > 0.5$ 。圆周只标开球边界, 图为解析教学构造。

为计算未被填充的环, 需要把端点抵消与高阶填充分别记录。选定顶点次序后, 以 $[v_0, \dots, v_k]$ 表示有向单纯形, 交换两顶点使符号反转。有向 k 维单纯形的实系数线性组合称为 k 维链, 组成向量空间 $C_k(\mathcal{X}; \mathbb{R})$ 。边界算子读取每个面的有向边缘:

$$\partial_k[v_0, \dots, v_k] = \sum_{i=0}^k (-1)^i [v_0, \dots, \widehat{v_i}, \dots, v_k], \quad k \geq 1, \quad (7.18)$$

尖帽表示删去该顶点, 算子线性延伸到全部链。本章采用非约化同调, 约定 $C_{-1} = \{0\}$ 、 $\partial_0 = 0$ 。例如 $\partial_1[1, 2] = [2] - [1]$, 端点的正负表示方向。

引理 7.14 边界的边界为零 上述算子满足

$$\partial_{k-1}\partial_k = 0, \quad k \geq 1. \quad (7.19)$$

证明. $k = 1$ 时由 $\partial_0 = 0$ 成立。对 $k \geq 2$, 固定 $i < j$, 两次删除 v_i, v_j 后得到相同的 $(k-2)$ 维面。先删 i 再删原来的 j , 系数为 $(-1)^i(-1)^{j-1}$; 先删 j 再删 i , 系数为 $(-1)^j(-1)^i$, 两者相反。所有项都按这样的顶点对成对抵消, 因此结论对基单纯形成立; 由线性性, 对全部链成立。■

边界再次取边界总是零，例如三角面的三条有向边首尾相接，端点恰好抵消。但反过来，一圈端点抵消的边未必是某个已有面的边界。要区分这两者，可以用上一章的核、像与商空间。

定义 7.15 闭链、边界与同调空间 满足 $\partial_k c = 0$ 的链称为闭链 (cycle)，能写成 $c = \partial_{k+1} b$ 的链称为边界 (boundary)。由 $\partial_k \partial_{k+1} = 0$ ，有 $\text{im } \partial_{k+1} \subseteq \ker \partial_k$ 。实系数同调空间 (homology space) 及其维数定义为

$$H_k(\mathcal{K}; \mathbb{R}) = \ker \partial_k / \text{im } \partial_{k+1}, \quad \beta_k = \dim H_k(\mathcal{K}; \mathbb{R}).$$

β_k 称为第 k 个 Betti 数 (Betti number)。

商空间沿用定义 6.1：两个闭链相差一个边界时被视为同类。因而 H_k 保留的不是全部闭链，而是无法用已有高阶填充消去的部分； β_0 计算连通分支， β_1 计算实系数意义下独立的一维环。

取 $\mathcal{K}_{\text{loop}} = \{\{1\}, \{2\}, \{3\}, \{1, 2\}, \{2, 3\}, \{1, 3\}\}$ 。链 $c = [1, 2] + [2, 3] - [1, 3]$ 的端点逐一抵消，故 $\partial_1 c = 0$ 。 ∂_1 的秩为 2，由边组成的闭链空间维数为 $3 - 2 = 1$ ，而没有二维面，故 $\beta_1 = 1$ 、 $\beta_0 = 3 - 2 = 1$ 。加入 $[1, 2, 3]$ 后， $c = \partial_2[1, 2, 3]$ 成为边界， β_1 降为 0； ∂_1 不变，所以 β_0 仍为 1。图 7.2 只改变面集合，顶点与边保持相同。




图 7.2 一圈边是否已填充，取决于高阶面而非边图。左侧闭链 $c = [1, 2] + [2, 3] - [1, 3]$ 不是边界；右侧加入 $[1, 2, 3]$ 后有 $c = \partial_2[1, 2, 3]$ 。两者 $\beta_0 = 1$ ， β_1 分别为 1 与 0。图为组合教学示例，不代表某个观测点云的真实拓扑。

复形的规模还依赖邻域尺度。开带 $\mathcal{M}_{\text{strip}}$ 与开矩形同胚，中心线 $\mathcal{C}$ 与开区间同胚，都没有全局环。闭合中心线得到圆，保留横向自由度并闭合则得到二维环带；维数不同，但都保留绕中心的一维环。只有在采样和尺度适当时，样本复形才有理由反映这些区别。尺度太小会让本来相连的区域因缺少样本而断开；太大则可能把环境中接近、沿原对象却相距很远的部分直接连起来，并用高阶面填掉原来的环。

单一尺度可能把采样空隙当成孔洞，也可能把真实孔洞填平。持续同调 (persistent homology) 因此跟踪尺度逐渐增大时，同调类何时出现、何时

消失。存在于较宽尺度范围内的结构提供了跨尺度信息，但仍不能仅凭持续时间就认定它对应任务中的真实结构。若 N_k 是 k 维单纯形数，Euler 示性数 $\chi = \sum_k (-1)^k N_k$ 是更粗的摘要：空心三角形为 $3 - 3 = 0$ ，填充三角形为 $3 - 3 + 1 = 1$ 。由秩-零度关系 $N_k = \beta_k + \text{rank } \partial_k + \text{rank } \partial_{k+1}$ ，交替求和后中间秩抵消，也得到 $\chi = \sum_k (-1)^k \beta_k$ 。不同 Betti 数组甚至不同拓扑都可能有一个 χ ，一个标量不足以代替分别分析。

用硬阈值连边时，两点距离只要稍微超过阈值，就会从相连突然变成不相连。为了记录接近程度，可以改用软关系，以 $\mu_{i,j} \in [0, 1]$ 表示所选局部尺度下的连接强度；这只是隶属度，不自动是事件概率。高阶强度例如可取全部边强度的最小值，但必须声明采用哪种规则。一种常见的合并运算是

$$a \sqcup b = a + b - ab = 1 - (1 - a)(1 - b), \quad a, b \in [0, 1]. \quad (7.20)$$

结果仍在 $[0, 1]$ 内；交换性由对称式给出，结合性由 $1 - (1 - a)(1 - b)(1 - c)$ 给出，0 为恒等元，任一输入为 1 时输出为 1。这些代数性质说明它可以用来合并连接强度。虽然公式看起来像独立事件的并集概率，这里却只给了两个强度值，没有定义相应的随机事件和联合分布。因此，数值处于 $[0, 1]$ 内还不足以让连接强度成为概率。核权重、相似度和置信度也可能处于这个区间，但它们各自的含义、概率解释与校准要求仍需分别说明。

UMAP 等方法由局部距离构造带强度的关系，再优化低维坐标以匹配这些关系；具体目标与优化过程留给第三卷“模型”的“降维”章。低维图像中的分离簇或孔洞还可能受邻居数、尺度、初始化与优化误差影响。拓扑方法不能修复错误的局部输入：跨折捷径会被忠实组合，完全漏采的区域也无法凭空恢复。采样覆盖、局部关系与尺度共同限制结论。

前面的群作用允许复合任意两个群元素，坐标过渡却有起点区域和终点区域：只有第一个过渡的输出落入第二个过渡的定义域，两者才能复合。若要统一记录这种带起终点的变换，可以使用范畴 (category)。它把区域等作为对象，把对象之间的映射作为箭头，并为各对象保留恒等箭头；仅在起终点匹配时复合箭头，复合满足结合律与恒等律。函子 (functor) 则把一套对象和箭头映到另一套，同时保持恒等与复合关系。例如，坐标区域与其间可复合的过渡就可按这种方式组织。这种语言帮助记录变换的衔接；距离重构和同调计算的保证，仍来自前面各自的条件。

7.2 非线性空间的局部线性化

坐标图记录位置，却还没有说明从当前位置可以怎样动。以下固定光滑流形模型，以局部参数化计算真实的一阶方向，再讨论只有样本时怎样估计

这些方向。解析模型与样本估计解决同一个局部问题，但它们的输入与保证不同。

7.2.1 已知参数化下的局部线性化

从 $\mathbf{p} = \varphi(\mathbf{z})$ 出发，坐标变化 $\mathbf{v}$ 经 Jacobian $\mathbf{J}_\varphi(\mathbf{z})$ 映为环境空间中的瞬时速度。切空间 (tangent space) 收集所有这样的可行速度；它描述一阶方向，并不是可行集合本身的一小块。

定义 7.16 嵌入流形的切空间 设 $\varphi : U \subseteq \mathbb{R}^d \rightarrow \mathcal{M} \subseteq \mathbb{R}^D$ 是局部参数化， $\mathbf{p} = \varphi(\mathbf{z})$ 。定义

$$T_{\mathbf{p}}\mathcal{M} = \{\mathbf{J}_\varphi(\mathbf{z})\mathbf{v} : \mathbf{v} \in \mathbb{R}^d\}. \quad (7.21)$$

Jacobian 列满秩保证这是 d 维向量空间，其原点是零速度。画在 $\mathbf{p}$ 旁边的仿射切平面则是 $\mathbf{p} + T_{\mathbf{p}}\mathcal{M}$ ；点的位置与速度向量的零点不能混为一谈。

引理 7.17 曲线速度与坐标刻画相容 $T_{\mathbf{p}}\mathcal{M}$ 恰是全部光滑曲线 $\gamma : (-\epsilon, \epsilon) \rightarrow \mathcal{M}$ 、 $\gamma(0) = \mathbf{p}$ 的速度 $\gamma'(0)$ 组成的集合，并且与局部坐标选择无关。

证明. 在足够小的参数区间内，曲线落入当前坐标图，写成 $\gamma(t) = \varphi(\mathbf{z}(t))$ 。链式法则给出 $\gamma'(0) = \mathbf{J}_\varphi(\mathbf{z})\mathbf{z}'(0)$ ，故每个曲线速度都属于所定义的空间。反过来，任意 $\mathbf{v} \in \mathbb{R}^d$ 给出曲线 $t \mapsto \varphi(\mathbf{z} + t\mathbf{v})$ ；因为 U 开，足够小的 t 仍在定义域内，其初速度为 $\mathbf{J}_\varphi(\mathbf{z})\mathbf{v}$ 。

若另一参数化满足 $\tilde{\varphi} = \varphi \circ \psi$ ，坐标过渡 ψ 的 Jacobian 可逆，且 $\mathbf{J}_{\tilde{\varphi}} = \mathbf{J}_\varphi \mathbf{J}_\psi$ 。右乘可逆矩阵不改变值域，两张图因而给出同一切空间。 ■

在点带中直接求导，可核对两个自由度：

$$\frac{\partial \Phi}{\partial s} = \left(1 + \frac{u}{R}\right) \begin{bmatrix} -\sin(s/R) \\ \cos(s/R) \end{bmatrix}, \quad (7.22)$$

$$\frac{\partial \Phi}{\partial u} = \begin{bmatrix} \cos(s/R) \\ \sin(s/R) \end{bmatrix}. \quad (7.23)$$

因 $|u| < w < R$ ，第一列不为零，两列正交且线性无关；开带的切空间是整个 $\mathbb{R}^2$ 。中心线则只允许 $u = 0$ ，

$$T_{\Phi(s,0)}\mathcal{C} = \text{span}\{(-\sin(s/R), \cos(s/R))^T\}.$$

径向方向对开带可行，对中心线不可行。中心线的切线随位置转动，没有一条固定线性子空间等于各处的切空间。

图 7.3 上半部把切向速度画在点旁，下半部比较同一坐标增量对应的实际弧长。方向数目决定局部维数，坐标增量怎样换算为长度则留待度量处理。




图 7.3 开带与中心线的局部方向不同。取 $R = 2$ 、 $w = 0.3$ 。上图的两个参数方向属于二维开带，仅以中心线为对象时，径向方向不属于其切空间；箭头平移到 p 只是画法。下图取 $u = -0.25, 0.25$ ，同一 $\Delta s = 0.8$ 对应圆弧长度 0.7, 0.9。灰虚线为不纳入开带的边界，两图等比例绘制，均为解析教学示例。

切空间之所以适合近似，由 Taylor 展开说明。若参数化在当前邻域内二阶导数有界，则

$$\varphi(\mathbf{z} + \mathbf{h}) - \varphi(\mathbf{z}) = \mathbf{J}_\varphi(\mathbf{z})\mathbf{h} + O(\|\mathbf{h}\|_2^2). \quad (7.24)$$

一阶项属于切空间。把环境位移投到切空间的正交补，也就是法向空间时，一阶项被消去，只剩 $O(\|\mathbf{h}\|_2^2)$ 的余项。这是局部结论，常数依赖所选邻域及二阶导数界；不能将它延伸到任意大步长。法向偏离反映嵌入在环境中怎样弯曲，不等于后文要定义的内在曲率。二维开带的切空间已是整个环境平面，其法向空间只含零向量，所以位移没有法向分量。坐标线可以弯曲，并不因此产生相对于这个二维对象的法向误差。

若流形由约束 $F(\mathbf{x}) = \mathbf{0}$ 给出, 其中 $F: \mathbb{R}^D \rightarrow \mathbb{R}^{D-d}$ 在 $\mathbf{p}$ 附近光滑且 $\mathbf{J}_F(\mathbf{p})$ 行满秩, 就能选出 $D-d$ 列组成可逆方阵。重排坐标后, 定理 3.30 把这 $D-d$ 个变量解为其余 d 个变量的光滑函数, 后者便给出局部参数化。对约束内曲线求导得 $\mathbf{J}_F(\mathbf{p})\gamma'(0) = \mathbf{0}$; 所以切空间包含于该矩阵的核。参数化给出 d 维切空间, 秩-零度关系又说明核为 d 维, 故 $T_{\mathbf{p}}\mathcal{M} = \ker \mathbf{J}_F(\mathbf{p})$ 。满秩条件不能省略: $F(x, y) = x^2 + y^2$ 在原点导数为零, 核是整个平面, 但零水平集只有一个点, 真实可行速度只有零向量。

如果一个映射把流形上的位置送到另一个流形, 我们还要知道: 输入点按某个速度移动时, 输出点会按什么速度移动? 这需把位置映射转成切空间之间的线性映射。设 $F: \mathcal{M} \rightarrow \mathcal{N}$, 其坐标表达 $\psi^{-1} \circ F \circ \varphi$ 光滑, 则称 F 光滑。它在 $\mathbf{p}$ 处的微分 (differential) 把输入速度转成输出速度:

$$dF_{\mathbf{p}}(\mathbf{v}) = \left. \frac{d}{dt} F(\gamma(t)) \right|_{t=0}, \quad \gamma(0) = \mathbf{p}, \quad \gamma'(0) = \mathbf{v}.$$

若 $\mathbf{v} = \mathbf{J}_{\varphi}(\mathbf{z})\mathbf{a}$, 令 $\mathbf{w} = \psi^{-1}(F(\mathbf{p}))$, 则

$$dF_{\mathbf{p}}(\mathbf{v}) = \mathbf{J}_{\psi}(\mathbf{w})\mathbf{J}_{\psi^{-1} \circ F \circ \varphi}(\mathbf{z})\mathbf{a}. \quad (7.25)$$

右端只依赖初速度, 不依赖实现速度的曲线, 因此定义良好且线性。坐标变换时两侧的 Jacobian 因链式法则相互抵消; $dF_{\mathbf{p}}: T_{\mathbf{p}}\mathcal{M} \rightarrow T_{F(\mathbf{p})}\mathcal{N}$ 是几何映射, 矩阵只是其坐标记录。复合还满足 $d(H \circ F)_{\mathbf{p}} = dH_{F(\mathbf{p})} \circ dF_{\mathbf{p}}$ 。

对标量函数 $f: \mathcal{M} \rightarrow \mathbb{R}$, 微分读取速度引起的一阶数值变化。余切空间 (cotangent space) $T_{\mathbf{p}}^*\mathcal{M}$ 就是 $T_{\mathbf{p}}\mathcal{M}$ 的线性泛函空间, 泛函的含义沿用定义 5.17。有限维向量空间上的全部线性读取组成其对偶空间 (dual space); 所以 $df_{\mathbf{p}} \in T_{\mathbf{p}}^*\mathcal{M}$, 不是一个切向量。写局部坐标为 $(z^1, \dots, z^d)$ 时, 上标在这里是坐标编号而非迭代次数。坐标切基为 $\partial_i = \partial \varphi / \partial z^i$, 其对偶基 dz^i 满足 $dz^i(\partial_j) = \delta_{i,j}$, 也就是 $dz^i(\sum_j a^j \partial_j) = a^i$: 它读出速度的第 i 个坐标系数。于是

$$df = \sum_i \partial_i(f \circ \varphi) dz^i, \quad df\left(\sum_i a^i \partial_i\right) = \sum_i \partial_i(f \circ \varphi) a^i.$$

例如圆上 $f(\cos \theta, \sin \theta) = \cos \theta$, 角速度 a 对应的数值变化为 $-a \sin \theta$ 。要把这个线性读取规则表示成“最陡方向”, 还须指定方向长度, 所以梯度将在度量建立后定义。

7.2.2 观测样本下的局部线性化

只有 $\mathbf{x}_i = \mathbf{p}_i + \boldsymbol{\epsilon}_i$ 时, 参数化与潜在位置通常未知。我们可以考察附近样本主要沿哪些方向变化, 用这些方向近似真实切空间。局部 PCA (local principal component analysis) 就是按这个思路, 在小邻域中寻找主要的

线性变化方向。它用样本估计局部方向，而不是用计算结果重新定义真实流形。在当前例子中，希望估计二维带的两个方向，还是中心线的一个方向，取决于潜在对象的建模选择。

给观测 $\mathbf{x}_i$ 选择邻居索引集 N_i 和权重 $\alpha_{i,j} \geq 0$ 、 $\sum_{j \in N_i} \alpha_{i,j} = 1$ ，计算

$$\bar{\mathbf{x}}_i = \sum_{j \in N_i} \alpha_{i,j} \mathbf{x}_j, \quad \mathbf{C}_i = \sum_{j \in N_i} \alpha_{i,j} (\mathbf{x}_j - \bar{\mathbf{x}}_i)(\mathbf{x}_j - \bar{\mathbf{x}}_i)^\top. \quad (7.26)$$

若潜在维数 d 给定，取 $\mathbf{C}_i$ 最大 d 个特征值对应的正交特征向量 $\hat{\mathbf{U}}_i$ ，其列空间 $\hat{\mathcal{T}}_i$ 为估计方向子空间。若 d 未知，需另由谱和误差模型判断；不能把预先指定的特征向量数当成维数发现。局部均值消去样本位置偏移，但不保证等于 $\mathbf{p}_i$ 。

计算结果要与真实对象分开。 $T_{\mathbf{p}_i} \mathcal{M}$ 是潜在位置处的真实方向空间， $\hat{\mathcal{T}}_i$ 是从样本估计出的方向空间，二者都以零速度为原点。把估计方向空间平移到 $\bar{\mathbf{x}}_i$ 或 $\mathbf{x}_i$ 处，才得到图中画出的仿射切平面近似。若 $d < D$ ，一般环境噪声使 $\mathbf{x}_i \notin \mathcal{M}$ ，此时 $T_{\mathbf{x}_i} \mathcal{M}$ 甚至没有定义。二维开带是当前例外：小噪声下观测仍在开带内，其切空间仍为 $\mathbb{R}^2$ ，但这不表示已经识别出生成它的潜在位置。

式 (7.24) 解释了误差来源。在正则局部坐标中，邻域尺度为 h 时，切向位移通常为 $O(h)$ ，嵌入法向偏离为 $O(h^2)$ 。若采样在各切方向上充分展开，切向协方差特征值具有 h^2 量级；法向位移的平方贡献至多为 $O(h^4)$ ，是否达到这个量级还取决于嵌入怎样弯曲。这里，二阶导数界控制法向余项，非退化局部采样保证切方向的变化被充分记录；仅说流形光滑，并不足以保证协方差中有可辨别的谱间隙。

上一章的子空间扰动结论可用于把误差变成方向误差：先选定一个前 d 个特征方向恰好张成真实切空间的理想局部协方差。若它的第 d 与第 $d+1$ 特征值间有间隙 $\delta > 0$ ，而观测协方差与它的差 $\mathbf{E}$ 相对 δ 足够小，就可以用 $\|\mathbf{E}\|_2/\delta$ 控制估计子空间的偏转。这里 $\mathbf{E}$ 要包括有限样本波动、噪声、邻域错选及非线性近似误差，不能只代入测量噪声方差。

缩小邻域会降低法向二阶偏差，却减少样本并压低真实信号的谱尺度；固定噪声不会随之自动消失。邻域过大时，中心线不同位置的切线已经明显转动，PCA 会把这些不同方向合在一起，结果未必接近中心点的切线。对二维窄带，若样本的横向覆盖不足或宽度小于噪声尺度，第二个方向可能难以稳定识别，但潜在对象并不因此变成一维。固定近邻数也不能解决非均匀密度带来的变化：稀疏处覆盖范围大，稠密处范围小。因此，邻域选择要同时考虑真实对象的维数、样本覆盖、局部弯曲与噪声：它们共同决定协方差中的主要方向是否能代表真实切空间。

即使局部方向估计准确，也尚未得到全局坐标。圆的每个邻域只有一个切方向，却不能以单张无断点实坐标图覆盖。局部 PCA 提供的是后续几何计算的局部输入，不是全局展开或任务语义正确性的保证。

7.3 流形上相同切空间下的度量、距离与运动

这里每次比较的两个向量，都属于同一个点处的切空间。沿路径时，速度可以属于随位置变化的切空间；计算长度只需在每个位置读出一个标量速度，再把这些标量累计起来，不需要先把不同位置的向量搬到一起。

7.3.1 同一点处的切向量度量

切空间给出可行的瞬时方向，却没有规定一单位坐标变化对应多大的实际长度。点带外侧与内侧相同的 ds 对应不同弧长，因而内积必须按位置指定。Riemann 度量 (Riemannian metric) 为每个切空间提供这种长度与夹角规则。

定义 7.18 Riemann 度量 光滑流形 $\mathcal{M}$ 上的 Riemann 度量 g 为每个 p 指定内积 $g_p : T_p\mathcal{M} \times T_p\mathcal{M} \rightarrow \mathbb{R}$ ，且在任一光滑坐标切基 ∂_i 中，矩阵 $G(\mathbf{z}) = [g_{i,j}(\mathbf{z})]$ 、 $g_{i,j} = g(\partial_i, \partial_j)$ 的条目光滑。每个 G 都对称正定。

对同点切向量 $\mathbf{v}, \mathbf{w}$ ，长度为 $\|\mathbf{v}\|_g = \sqrt{g_p(\mathbf{v}, \mathbf{v})}$ ；非零时夹角满足 $\cos \vartheta = g_p(\mathbf{v}, \mathbf{w}) / (\|\mathbf{v}\|_g \|\mathbf{w}\|_g)$ 。若它们的坐标分量为 $\mathbf{a}, \mathbf{b}$ ，内积是 $\mathbf{a}^\top G \mathbf{b}$ 。 G 既不是样本协方差，也不必是全空间共享的常矩阵。

嵌入流形可以限制环境欧氏内积，得到诱导度量：

$$G(\mathbf{z}) = J_\varphi(\mathbf{z})^\top J_\varphi(\mathbf{z}). \quad (7.27)$$

对非零 $\mathbf{a}$ ，满秩保证 $\mathbf{a}^\top G \mathbf{a} = \|J_\varphi \mathbf{a}\|_2^2 > 0$ 。若 Jacobian 退化，只会得到半正定形式；这不符合当前坐标中的 Riemann 度量条件。也可以另选光滑正定内积，但这样会改变几何，而不只是改写坐标。

若旧坐标 $\mathbf{z} = \psi(\mathbf{v})$ ，记可逆 Jacobian 为 $\mathbf{A} = J_\psi$ ，同一几何向量的旧分量等于 $\mathbf{A}$ 乘新分量，所以

$$\tilde{G}(\mathbf{v}) = \mathbf{A}^\top G(\psi(\mathbf{v})) \mathbf{A}. \quad (7.28)$$

因此 $\mathbf{a}^\top \tilde{G} \mathbf{b} = (\mathbf{A} \mathbf{a})^\top G(\mathbf{A} \mathbf{b})$ 。若换了向量的坐标分量，却仍使用旧度量矩阵，算出的长度通常会改变。按上式同时变换分量与度量矩阵，才是在新坐标中计算同一个几何长度。

点带的两个参数方向已在式 (7.22) 与 (7.23) 中求出, 故

$$G(s, u) = \begin{bmatrix} (1 + u/R)^2 & 0 \\ 0 & 1 \end{bmatrix}. \quad (7.29)$$

横向速度 $\dot{u}$ 的长度系数为 1, 纵向速度 $\dot{s}$ 的系数为 $1 + u/R$ 。在 $R = 2$ 、 $u = \pm 0.25$ 时, 同一 $\Delta s = 0.8$ 沿固定 u 的圆弧分别产生 0.9 与 0.7 的长度, 与图 7.3 一致。内积权重来自坐标尺度, 并不由该位置采到了多少点决定。

7.3.2 沿路径的速度与长度

设分段光滑路径 $\gamma: [a, b] \rightarrow \mathcal{M}$ 在一张图中写成 $\gamma(t) = \varphi(\mathbf{z}(t))$ 。链式法则保证 $\dot{\gamma}(t) \in T_{\gamma(t)}\mathcal{M}$, 度量读出的平方速度为

$$\|\dot{\gamma}(t)\|_g^2 = \dot{\mathbf{z}}(t)^\top G(\mathbf{z}(t)) \dot{\mathbf{z}}(t). \quad (7.30)$$

将标量速度按时间累计, 定义路径长度

$$L_g(\gamma) = \int_a^b \sqrt{\dot{\mathbf{z}}(t)^\top G(\mathbf{z}(t)) \dot{\mathbf{z}}(t)} dt. \quad (7.31)$$

整条路径不在同一张图时, 将紧区间 $[a, b]$ 分成有限段, 使每段落入一张图, 再求长度之和。紧致的路径像和坐标开覆盖保证能作这种有限分段。

这种计算不依赖坐标。在 $\mathbf{z} = \psi(\mathbf{v})$ 下, $\dot{\mathbf{z}} = \mathbf{A}\dot{\mathbf{v}}$, 式 (7.28) 给出 $\dot{\mathbf{v}}^\top \tilde{\mathbf{G}} \dot{\mathbf{v}} = \dot{\mathbf{z}}^\top \mathbf{G} \dot{\mathbf{z}}$ 。每段被积的标量相同, 所以重叠区域选哪张图、怎样进一步细分都不改变长度。

长度也不依赖沿同一路线前进的快慢。对保持方向的光滑重参数化 $t = \tau(r)$, 新速度为 $\dot{\gamma}(\tau(r))\tau'(r)$, 其长度因子为 $|\tau'(r)|$; 当 $\tau' > 0$ 时, 积分换元 $dt = \tau'(r)dr$ 给出相同总长。反向的光滑单调参数化配合积分端点互换也不改变长度。允许停顿的分段正则重参数化可分段处理; 来回多走则改变路线的经过次数, 不属于仅仅换速度。

瞬时切向可行不等于环境直线可行。单位圆上 $\mathbf{p} = (1, 0)^\top$ 、 $\mathbf{v} = (0, 1)^\top \in T_{\mathbf{p}}\mathbb{S}^1$, 但 $\|\mathbf{p} + t\mathbf{v}\|_2 = \sqrt{1 + t^2} > 1$ 对 $t \neq 0$ 成立。速度只描述路径的一阶变化, 保持有限步可行仍需在曲面上构造完整路径或更新映射。

7.3.3 固定端点间的测地距离与近似

路径长度评价一条已经给出的路线。端点固定而路线可选时, 要比较所有允许的路线; 完整空间已知和只有有限采样是这个问题的两种信息条件。

7.3.3.1 连续空间下的测地距离

定义 7.19 测地距离 在 Riemann 流形 (M, g) 的同一路径连通分支内, 定义 测地距离 (geodesic distance) 为连接两点的全部分段光滑路径长度的下确界:

$$d_g(\mathbf{p}, \mathbf{q}) = \inf_{\substack{\gamma(a)=\mathbf{p} \\ \gamma(b)=\mathbf{q}}} L_g(\gamma). \quad (7.32)$$

若无连接路径, 约定值为 $+\infty$; 在可能不连通的整个空间上, 它是扩展距离。

这里的定义尚不要求存在最短路径, 更不依赖测地线方程。反向路径给出对称性, 拼接两条近似最短路径给出三角不等式。在一个足够小的坐标邻域内, 按度量计算的向量长度, 可以用其坐标向量的欧氏长度乘以两个固定正常数从上下控制。这保证不同点之间的路程不能趋于零, 因而每个连通分支中确实得到度量。

对于欧氏诱导度量, 由 $\mathbf{q} - \mathbf{p} = \int_a^b \dot{\gamma}(t) dt$ 与三角不等式, 每条连接路径均满足 $\|\mathbf{q} - \mathbf{p}\|_2 \leq L_g(\gamma)$, 所以

$$\|\mathbf{q} - \mathbf{p}\|_2 \leq d_g(\mathbf{p}, \mathbf{q}).$$

若连接线段完全可行, 就取等。反过来, 只有下确界被允许路径达到时, 取等才迫使该最短路径沿线段行进, 至多改变速度; 若没有最短路径, 距离也可能只是不断接近环境线段长度; 仅凭两种距离相等, 不能断定线段属于可行域。若换成任意非诱导度量, 上述环境距离比较也不能照搬。

回到开中心线的两点 $\mathbf{p} = \Phi(s, 0)$ 、 $\mathbf{q} = \Phi(t, 0)$ 。环境空间的弦长是

$$\|\Phi(s, 0) - \Phi(t, 0)\|_2 = 2R \left| \sin \frac{s-t}{2R} \right|. \quad (7.33)$$

中心线以 s 为弧长参数, 允许路径必须留在开弧内, 因此 $d_c(\mathbf{p}, \mathbf{q}) = |s-t|$ 。二维带允许路径向内侧绕行, 中心线弧只是候选, 故

$$\|\mathbf{p} - \mathbf{q}\|_2 \leq d_{\mathcal{M}_{\text{strip}}}(\mathbf{p}, \mathbf{q}) \leq d_c(\mathbf{p}, \mathbf{q}) = |s-t|.$$

带宽、端点位置和允许域决定第二个不等式是否严格; 不能把这两种距离都称为不加区分的“沿带距离”。

另取完整单位圆作为独立例子。夹角 $0 \leq \theta \leq \pi$ 时, 允许选择短弧, 内在距离为 θ , 弦长为 $2\sin(\theta/2)$ 。在 $\theta = \pi/2$ 时两者为 $\pi/2$ 与 $\sqrt{2}$; 小角度展开 $2\sin(\theta/2) = \theta - \theta^3/24 + O(\theta^5)$ 说明局部接近, 全局却不同。图 7.4 在相同尺度上比较这两种量。




图 7.4 完整单位圆的测地距离与环境弦长。左图夹角为 $\pi/2$ ，蓝线为圆上的允许短弧，红虚线为穿过圆内的环境线段；右图比较 $\theta \in [0, \pi]$ 时的两种长度。完整圆允许选择两段弧中的较短者，不能与开中心线或二维开带的允许路径混用。图为解决教学示例。

为什么定义取下确界，而不直接取最小值？因为允许的路径未必包含一条最短路径。在穿孔平面 $\mathbb{R}^2 \setminus \{0\}$ 中， $(-1, 0)^T$ 与 $(1, 0)^T$ 之间可以沿横轴接近原点，在原点附近绕一段半径任意小的半圆，再沿横轴到终点。这些路径的长度趋于 2，但长度恰为 2 的直线路径会穿过被删去的原点。哪些全局条件保证达到下确界，将在固定端点的最短路径问题中讨论。

7.3.3.2 有限采样下的测地距离近似

只有观测点时，常把距离小于阈值 ε 的点相连，或连接每个点的 k 个最近邻，再以 $\|\mathbf{x}_i - \mathbf{x}_j\|_2$ 为边长。一条边路径的长度是所经边长之和，最短边路径试图近似所选潜在流形上 $d_g(\mathbf{p}_i, \mathbf{p}_j)$ 。这里只借用顶点、边和路径的直观含义，通用图算法留给第 3 部分。

潜在对象必须先定。若观测不在潜在流形上， $d_g(\mathbf{x}_i, \mathbf{x}_j)$ 便未定义；即使观测在二维开带内，也不能因此把它认作 $\mathbf{p}_i$ 。环境欧氏边长自然对应欧氏诱导度量的局部近似；若目标采用另一个 Riemann 度量，就要据此修正边长，不能继续沿用欧氏弦长而声称目标未变。

邻域应足够小，使每条边只连接潜在流形上近似平直的一小段，避免把环境中靠得很近、沿流形却相距很远的两段直接相连；又要大到样本间的空隙能够连通。若连边阈值超过这两段之间的环境间隔，就会引入捷径，低估沿潜在空间的距离；若阈值连相邻样本之间的空隙也跨不过去，就会拆开本来相连的区域，返回无穷距离。即使没有捷径，局部弦长误差与离散路径绕行误差也会共同作用，不能无条件断言估计总在真实距离的同一侧。

固定 k 并不固定几何尺度。稀疏处第 k 个邻居可能很远，稠密处则很近，有向近邻关系还可能不对称，需要声明如何对称化。一致近似通常要求潜在流形光滑、采样在所研究区域逐渐稠密、噪声相对邻域尺度受控，并让邻域半径随样本量缩小而仍足以覆盖采样空隙。非紧开带若只在一部分采样，这些要求也只支持相应覆盖区域的结论。具体收敛速度须结合采样分布与尺度选择证明，最短边路径正确更不自动意味着后续全局坐标恢复正确。

7.3.4 度量诱导的体积与积分

沿路径积分只覆盖一条路线。若要在整个曲面上累计函数值或变化量，就需要知道每个小区域占多大面积；更高维时，相应的量是体积。坐标切基围成的微小平行体，其平方体积是 Gram 行列式 $\det \mathbf{G}$ ，因此几何体积元为

$$dV_g = \sqrt{\det \mathbf{G}(\mathbf{z})} d\mathbf{z}. \quad (7.34)$$

这是由度量产生的测度密度，不要求先为流形选定全局朝向。一维时给出长度，二维时给出面积。

坐标变换 $\mathbf{z} = \psi(\mathbf{v})$ 下， $\det \tilde{\mathbf{G}} = (\det \mathbf{A})^2 \det \mathbf{G}$ ，所以

$$\sqrt{\det \tilde{\mathbf{G}}} d\mathbf{v} = \sqrt{\det \mathbf{G}(\psi(\mathbf{v}))} |\det \mathbf{A}| d\mathbf{v}.$$

它正是多元积分换元中的 Jacobian 因子，故对可积函数所得积分不依赖坐标。跨图时必须避免把重叠区域重复计数，可分割成可测片段分别积分；光滑计算也可使用从属于图册、和为 1 的局部权重来拼接。

点带中 $\sqrt{\det \mathbf{G}} = 1 + u/R > 0$ ，小盒 $ds du$ 在外侧对应较大面积。中心线限制为 $u = 0$ 后的一维体积元是 ds ，不是把二维面积直接代入。若样本相对几何体积有密度 q ，其分布测度是 $q dV_g$ ；简单样本平均近似该加权积分，并非自动近似 $\int f dV_g$ 。几何体积与采样权重的差别将在离散平滑目标中再次出现。

当前开带无流形边界，但不是紧集。需要边界积分时，将另取有分片光滑边界的截断闭域，并声明函数在边界的行为；不能只因图上画有虚线就把它当作同一个积分问题。

7.4 流形上不同切空间的比较与曲率

沿路径计算长度时，每个位置只输出一个标量。若要问速度有没有转弯，或相邻两点的方向是否一致，就必须比较不同切空间中的向量。即使流形嵌在同一个欧氏空间内，直接相减也可能产生法向分量：圆上恒速运动的速度导数指向圆心，却没有沿圆加速。需要把环境变化与流形内的方向变

化分开。下面建立联络、测地运动和曲率，所用的 Riemann 几何基础可参见 Lee 的教材²。

² J. M. Lee, *Introduction to Riemannian Manifolds*, Springer, 2018, 2nd ed.

7.4.1 不同切空间的比较规则

在每个位置指定一个可行方向，得到向量场。跨点比较规则应使其导数仍为切向量，还应遵守加法和乘积求导；联络就是满足这些要求的微分规则。它不是把所有切空间强行认成同一个空间，而是在局部说明怎样比较变化。

定义 7.20 向量场与联络 光滑向量场 (vector field) V 在每个 $p \in \mathcal{M}$ 选取 $V(p) \in T_p\mathcal{M}$ ，其坐标分量光滑。联络 (connection) 为两个光滑向量场 U, V 指定向量场 $\nabla_U V$ ，称为 V 沿 U 的协变导数 (covariant derivative)，并满足

$$\begin{aligned}\nabla_{fU+hW} V &= f\nabla_U V + h\nabla_W V, \\ \nabla_U(aV+bW) &= a\nabla_U V + b\nabla_U W, \\ \nabla_U(fV) &= U(f)V + f\nabla_U V.\end{aligned}$$

其中 f, h 为光滑函数， $a, b \in \mathbb{R}$ ， $U(f) = df(U)$ 为方向导数。

第一条允许求导方向的系数是光滑函数，第二条只允许被求导向量场的系数是常数，第三条说明为什么不能把第二条的常数任意换成光滑函数：系数本身的变化必须保留。欧氏空间的普通方向导数满足这三项规则；一般流形上，单独求坐标分量的导数不够，因为坐标切基本身也在变。

度量已经规定长度，新的导数应当与这一判断相容。此外，非坐标方向场先后作用的顺序本来就可能不同，不能把这种差异误认为额外的几何扭转。定义交换子 $[U, V]$ 为对任意光滑 f 满足

$$[U, V](f) = U(V(f)) - V(U(f))$$

的向量场；在坐标基下，其第 k 个分量为 $\sum_i (U^i \partial_i V^k - V^i \partial_i U^k)$ 。坐标方向 ∂_i, ∂_j 的交换子为零，一般方向场则未必。

示例 7.21 平面上不可交换的方向场 在欧氏平面取 $U = \partial_x$ 、 $V = x\partial_y$ 。 U 始终沿 x 轴， V 沿 y 轴但其大小随 x 改变。对任意光滑函数 f ，

$$U(V(f)) = \partial_y f + x\partial_x \partial_y f, \quad V(U(f)) = x\partial_y \partial_x f,$$

故 $[U, V] = \partial_y$ 。先沿 x 方向移动，会改变随后沿 V 移动的速度；两个方向场的顺序差异在平面上就会出现。欧氏空间的普通方向导数还给出

$$\nabla_U V = \partial_y, \quad \nabla_V U = 0.$$

二者之差恰是交换子。这个平坦例子说明，方向场本身随位置变化所产生的差异，需要与几何结构额外产生的差异分开。

定义 7.22 Levi-Civita 联络 给定 Riemann 度量 g ，同时满足下列度量相容与无挠条件的联络，称为它的 Levi-Civita 联络 (Levi-Civita connection)：

$$\begin{aligned} U(g(V, W)) &= g(\nabla_U V, W) + g(V, \nabla_U W), \\ \nabla_U V - \nabla_V U &= [U, V]. \end{aligned}$$

度量相容使内积的求导仍满足乘积法则；无挠规定联络在交换两个方向场时，不产生交换子之外的差异。无挠不声称 $\nabla_U \nabla_V W = \nabla_V \nabla_U W$ ，后者涉及本节末尾的曲率。

每个光滑 Riemann 度量唯一确定这样的联络。其唯一性可以从两项条件直接看出：轮换 U, V, W 的度量相容等式，并用无挠条件消去交换项，得到

$$\begin{aligned} 2g(\nabla_U V, W) &= Ug(V, W) + Vg(W, U) - Wg(U, V) \\ &\quad + g([U, V], W) - g([V, W], U) + g([W, U], V). \end{aligned} \quad (7.35)$$

右端只含已知度量、向量场和普通方向导数；正定性使其唯一确定 $\nabla_U V$ 。反过来，用此式定义该向量场，代入可检查联络的三条规则、度量相容和无挠条件，因而也给出存在性。这个公式的用途是确定比较规则，实际计算通常使用坐标系数或环境投影。

对继承欧氏度量的嵌入流形，设 P_p 为环境空间到 $T_p \mathcal{M}$ 的正交投影，则

$$\nabla_U V(p) = P_p dV_p(U(p)). \quad (7.36)$$

这里把 V 视为取值于环境 $\mathbb{R}^D$ 的映射，先求环境导数再投影。投影保持对切向量的内积，所以欧氏内积的乘积法则给出度量相容；环境方向导数之差是已经切向的交换子，投影后仍不变，故也无挠。由唯一性，这正是诱导度量的 Levi-Civita 联络。若度量不是环境诱导度量，不能继续沿用这个欧氏正交投影公式。

7.4.2 给定路径下的平行移动

现在固定路径 $\gamma(t)$ 和起点切向量, 希望沿路保持方向。“保持”不是要求环境坐标分量不变, 而是要求联络测得的变化为零。在坐标基中写 $\nabla_{\partial_i} \partial_j = \sum_k \Gamma_{i,j}^k \partial_k$, 则沿 $\gamma(t) = \varphi(\mathbf{z}(t))$ 的向量 $\mathbf{V}(t) = \sum_j V^j(t) \partial_j$ 满足

$$\frac{D\mathbf{V}}{dt} = \sum_k \left(\dot{V}^k + \sum_{i,j} \Gamma_{i,j}^k(\mathbf{z}(t)) \dot{z}^i V^j \right) \partial_k. \quad (7.37)$$

第一项是分量变化, 第二项修正坐标切基的变化; 合起来才是坐标无关的协变导数。对于欧氏诱导度量, 式 (7.36) 沿路径写成

$$\frac{D\mathbf{V}}{dt} = \mathbf{P}_{\gamma(t)} \frac{d\mathbf{V}}{dt},$$

保留环境导数的切向部分。

定义 7.23 平行移动 给定分段光滑路径 $\gamma : [a, b] \rightarrow \mathcal{M}$ 和 $\mathbf{v} \in T_{\gamma(a)}\mathcal{M}$, 沿路解

$$\frac{D\mathbf{V}}{dt} = \mathbf{0}, \quad \mathbf{V}(a) = \mathbf{v}.$$

终值定义线性映射 $P_\gamma : T_{\gamma(a)}\mathcal{M} \rightarrow T_{\gamma(b)}\mathcal{M}$, 称为沿 γ 的平行移动 (parallel transport)。

坐标式是具有连续系数的线性常微分方程, 初值唯一决定解; 沿有限段路径逐图求解并拼接即可, 不要求流形完备。反向路径给出逆映射, 拼接路径对应映射复合。对于 Levi-Civita 联络,

$$\frac{d}{dt} g(\mathbf{V}, \mathbf{W}) = g(D\mathbf{V}/dt, \mathbf{W}) + g(\mathbf{V}, D\mathbf{W}/dt) = 0$$

用于任意两个平行向量场。因此 P_γ 保持长度和夹角。这个结论依赖度量相容, 不能对任意联络直接宣称保距。

欧氏空间的直角坐标中 $\Gamma_{i,j}^k = 0$, 平行移动保持向量的分量不变, 且与路径无关。球面则不同: 向量必须始终切向, 环境分量通常会改变, 不同路径的终值也可能不同。

示例 7.24 球面三段路径上的方向搬运 在诱导度量的单位球面 $\mathbb{S}^2$ 上, 取 $N = (0, 0, 1)^\top$ 、 $A = (1, 0, 0)^\top$ 、 $B = (0, 1, 0)^\top$ 。记三个坐标轴的

单位向量为 $\mathbf{e}_x, \mathbf{e}_y, \mathbf{e}_z$ 。沿三条四分之一大圆弧 $N \rightarrow A \rightarrow B \rightarrow N$ 搬运初始向量 $\mathbf{V}(N) = \mathbf{e}_x$ 。各段用 $t \in [0, \pi/2]$ 参数化：

路径	$\gamma(t)$	$\mathbf{V}(t)$
$N \rightarrow A$	$(\sin t, 0, \cos t)^\top$	$(\cos t, 0, -\sin t)^\top$
$A \rightarrow B$	$(\cos t, \sin t, 0)^\top$	$(0, 0, -1)^\top$
$B \rightarrow N$	$(0, \cos t, \sin t)^\top$	$(0, \sin t, -\cos t)^\top$

每段都有 $\gamma^\top \mathbf{V} = 0$ 与 $\|\mathbf{V}\|_2 = 1$ 。第一段 $\dot{\mathbf{V}} = -\gamma$ ，第二段 $\dot{\mathbf{V}} = \mathbf{0}$ ，第三段 $\dot{\mathbf{V}} = \gamma$ ，环境导数全部是法向或零，投影后的协变导数为零。两处接点的向量同为 $-\mathbf{e}_z$ ，故三段连续拼接。返回 N 时向量成为 $\mathbf{e}_y$ ，与初始 $\mathbf{e}_x$ 相差 $\pi/2$ 。若始终留在 N ，搬运则不改变向量，说明仅给起终点不能决定平行移动。

图 7.5 画出这些向量的沿路变化。在 $B \rightarrow N$ 段，向量与前进速度相反；保持方向不意味着向量必须指向前进方向。




图 7.5 单位球面上沿 $N \rightarrow A \rightarrow B \rightarrow N$ 的平行移动。蓝色为给定的三条大圆弧，红箭头为例 7.24 中逐段计算的切向量。沿路协变导数为零，返回 N 后的方向却由黄色初始箭头 $\mathbf{e}_x$ 变为红色终值箭头 $\mathbf{e}_y$ 。箭头在三维中等长，投影到纸面后的长度可以不同。图为解析教学示例。

这里的变换由路径和联络决定，不是任意选一个旋转来对齐环境向量。前文群作用规定的是输入在指定变换下的响应；平行移动规定的是沿几何路径的方向比较，即使二者有时都用矩阵表示，也不能据此互换。

7.4.3 不同条件下的测地运动与最短路径

平行移动把路径当作输入、向量场当作未知量。若要求路径自己的速度平行移动，路径也变成未知量。给定初速度时，这是运动方程的初值问题；只给两个端点时，还要决定该沿哪条路径前进，最短性是额外的比较要求。

7.4.3.1 初速度条件下的测地运动

定义 7.25 测地线 相对于 Riemann 流形的 Levi-Civita 联络，采用仿射参数的曲线 γ 若满足

$$\frac{D\dot{\gamma}}{dt} = \mathbf{0},$$

称为测地线 (geodesic)。

它没有切向加速度，速度沿自身路径作平行移动。度量相容进一步给出 $\frac{d}{dt}\|\dot{\gamma}\|_g^2 = 2g(D\dot{\gamma}/dt, \dot{\gamma}) = 0$ ，因此速度大小恒定。环境加速度仍可非零，例如球面大圆需要法向加速度才能留在球面。

“仿射参数”说明换元 $t = ar + b$ 、 $a \neq 0$ 保留这个方程。一般换元则产生

$$\frac{D}{dr} \frac{d\gamma}{dr} = (\tau'(r))^2 \frac{D\dot{\gamma}}{dt} + \tau''(r)\dot{\gamma}.$$

非匀速参数化可以描出相同几何轨迹，却不再满足零协变加速度。因此不能把路径长度的任意重参数化不变性照搬到这个运动方程。

要在坐标中求解，先用式 (7.35) 取 $\mathbf{U} = \partial_i, \mathbf{V} = \partial_j, \mathbf{W} = \partial_\ell$ 。坐标方向交换子为零，于是

$$2 \sum_k g_{k,\ell} \Gamma_{i,j}^k = \partial_i g_{j,\ell} + \partial_j g_{i,\ell} - \partial_\ell g_{i,j}.$$

乘逆度量便得到 Christoffel 符号

$$\Gamma_{i,j}^k = \frac{1}{2} \sum_{\ell=1}^d g^{k,\ell} \left(\frac{\partial g_{\ell,j}}{\partial z^i} + \frac{\partial g_{i,\ell}}{\partial z^j} - \frac{\partial g_{i,j}}{\partial z^\ell} \right), \quad [g^{i,j}] = \mathbf{G}^{-1}. \quad (7.38)$$

将 $\mathbf{V} = \dot{\gamma} = \sum_j \dot{z}^j \partial_j$ 代入式 (7.37)，测地条件成为

$$\ddot{z}^k + \sum_{i,j=1}^d \Gamma_{i,j}^k(\mathbf{z}) \dot{z}^i \dot{z}^j = 0. \quad (7.39)$$

要判断这组系数是否表示点处的几何对象，需要区分几何张量与一张普通分量表。这里的几何张量 (geometric tensor) 是点处、与坐标无关的多线性对象；换基只对它的各个输入和输出作线性变换。因此，零分量表换基

后仍为零。Christoffel 符号不满足这一规律。以正半轴的欧氏度量为例, 在坐标 $x > 0$ 中有 $g_{x,x} = 1$ 、 $\Gamma_{x,x}^x = 0$; 改用 $x = e^u$ 后, $g_{u,u} = e^{2u}$, 式 (7.38) 给出

$$\Gamma_{u,u}^u = \frac{1}{2} e^{-2u} \frac{d}{du} e^{2u} = 1.$$

所以 Christoffel 符号是联络的坐标系数, 不是张量。基向量的变化与这些系数共同组成协变加速度, 后者及所得曲线仍是几何对象。

有了这组坐标方程, 就能由起点和初速度计算运动。光滑系数使这个二阶方程在给定 $\gamma(0) = \mathbf{p}$ 、 $\dot{\gamma}(0) = \mathbf{v}$ 后具有局部唯一解, 并光滑依赖初值。这里的解首先只保证在一个足够短的时间区间内存在。路径走出当前坐标区域时, 可以换图继续; 但若它在有限时间到达流形之外的缺口, 就无法这样延拓。开单位球内的欧氏直线从原点出发, 以速度 $2\mathbf{e}_1$ 前进, 在 $t = 1/2$ 时便到达不属于该流形的边界, 不能默认解存在至 $t = 1$ 。

定义 7.26 指数映射 对给定 $\mathbf{p}$, 若初速度 $\mathbf{v}$ 的测地线 $\gamma_{\mathbf{v}}$ 存在至 $t = 1$, 定义

$$\text{Exp}_{\mathbf{p}}(\mathbf{v}) = \gamma_{\mathbf{v}}(1).$$

它称为 $\mathbf{p}$ 处的指数映射 (exponential map), 其定义域至少包含 $T_{\mathbf{p}}\mathcal{M}$ 中零向量的一个邻域。

初速度缩放对应时间缩放: $\text{Exp}_{\mathbf{p}}(t\mathbf{v}) = \gamma_{\mathbf{v}}(t)$, 只在两边均有定义时使用。因而 $\text{Exp}_{\mathbf{p}}(\mathbf{0}) = \mathbf{p}$ 且 $d(\text{Exp}_{\mathbf{p}})_{\mathbf{0}} = \text{id}_{T_{\mathbf{p}}\mathcal{M}}$ 。逆函数定理保证在足够小邻域中它是微分同胚; 这为用切向量表示附近点提供了一种局部方式, 不保证全局一一对应。

单位球面上, $\mathbf{v} \perp \mathbf{p}$ 、 $r = \|\mathbf{v}\|_2$ 时,

$$\text{Exp}_{\mathbf{p}}(\mathbf{v}) = \cos r \mathbf{p} + \frac{\sin r}{r} \mathbf{v}, \quad (7.40)$$

$r = 0$ 时按连续延拓取 $\mathbf{p}$ 。对应曲线 $\gamma(t) = \cos(tr)\mathbf{p} + \sin(tr)\mathbf{v}/r$ 满足 $\|\gamma(t)\|_2 = 1$ 、初速度为 $\mathbf{v}$, 且 $\ddot{\gamma} = -r^2\gamma$ 为纯法向, 所以确实解测地线方程。所有方向上长度为 π 的初速度都到达对跖点 $-\mathbf{p}$; 即使映射处处有定义, 也未必全局单射。

7.4.3.2 固定端点条件下的最短路径

现在给定 $\mathbf{p}, \mathbf{q}$, 要找一条长度真正等于式 (7.32) 中下确界的路径。要说明最短路径为什么满足测地线方程, 可以先把长度问题转成更便于求导的能量问题。固定时间区间 $[a, b]$, 定义

$$E(\gamma) = \frac{1}{2} \int_a^b \|\dot{\gamma}\|_g^2 dt.$$

由 Cauchy-Schwarz 不等式, $L_g(\gamma)^2 \leq 2(b-a)E(\gamma)$, 等号恰对应几乎处处恒定的速度大小。因此对可作匀速参数化的非退化路径, 最小化长度可联系到固定时间的能量最小化; 能量本身却不具有长度那样的任意重参数化不变性。

在局部坐标中, Lagrange 函数为 $\mathcal{L}(\mathbf{z}, \dot{\mathbf{z}}) = \frac{1}{2} \sum_{i,j} g_{i,j}(\mathbf{z}) \dot{z}^i \dot{z}^j$ 。取光滑扰动 $\mathbf{h}$, 满足 $\mathbf{h}(a) = \mathbf{h}(b) = \mathbf{0}$, 并令 $\mathbf{z}_\varepsilon(t) = \mathbf{z}(t) + \varepsilon \mathbf{h}(t)$ 。取足够小的 ε 使路径仍在坐标域内。若 φ 为当前坐标的参数化, 一阶变分就是把整条路径沿这个方向改变后, 能量关于扰动幅度的导数:

$$\delta E[\mathbf{h}] = \left. \frac{d}{d\varepsilon} E(\varphi \circ \mathbf{z}_\varepsilon) \right|_{\varepsilon=0}.$$

对积分求导并分部积分, 得到

$$\delta E[\mathbf{h}] = \int_a^b \sum_k \left(\frac{\partial \mathcal{L}}{\partial z^k} - \frac{d}{dt} \frac{\partial \mathcal{L}}{\partial \dot{z}^k} \right) h^k dt.$$

边界项因固定端点消失。驻定要求任意这样的 $\mathbf{h}$ 都使变分为零, 因此括号中每个系数都必须为零: 若某个连续系数在一点非零, 就在它保持同号的小邻域内取一个同号、光滑且在邻域外为零的扰动, 相应积分便不为零, 产生矛盾。计算括号中的两个偏导得

$$\begin{aligned} \frac{\partial \mathcal{L}}{\partial z^k} &= \frac{1}{2} \sum_{i,j} \partial_k g_{i,j} \dot{z}^i \dot{z}^j, \\ \frac{d}{dt} \frac{\partial \mathcal{L}}{\partial \dot{z}^k} &= \sum_j g_{k,j} \ddot{z}^j + \sum_{i,j} \partial_i g_{k,j} \dot{z}^i \dot{z}^j. \end{aligned}$$

对第二行的速度乘积对称化后, Euler-Lagrange 方程为

$$\sum_j g_{k,j} \ddot{z}^j + \frac{1}{2} \sum_{i,j} (\partial_i g_{k,j} + \partial_j g_{k,i} - \partial_k g_{i,j}) \dot{z}^i \dot{z}^j = 0.$$

乘 $\mathbf{G}^{-1}$ 即得式 (7.39)。跨图路径可对各段内支撑的扰动分别推导, 得到相同几何方程。这说明光滑匀速最短路必为测地线, 不说明每个能量驻点都是最短路。

指数映射给出描述这些局部路径的区域。取零切向量附近的小开集 V , 要求 $\mathbf{v} \in V$ 时 $t\mathbf{v} \in V$ 对 $0 \leq t \leq 1$ 成立, 且 $\text{Exp}_{\mathbf{p}}$ 在 V 上为微分同胚。它的像称为 $\mathbf{p}$ 的正规邻域 (normal neighborhood), 其中每个点都用一个初速度表示, 径向路径对应 $t\mathbf{v}$ 。标准局部最短性结论保证可以把这个区域取到足够小, 使径向测地线段在邻域内达到端点间的最短长度。还可进一步选择凸正规邻域 (convex normal neighborhood), 让其中任意两点由唯一的邻域内最短测地线连接, 整条线段留在该邻域中。这里“凸”指测地线连接的性质, 不是要求环境中的欧氏直线段留在区域内。这项结论利用

指数映射和径向、横向变化的正交性，不是只凭微分方程存在唯一性得到的。离开这种局部范围后，其他路线可能更短。若一段测地线达到 d_g ，称为长度最短测地线 (length-minimizing geodesic)。

完整单位圆上，从 $(1, 0)^T$ 到 $(0, -1)^T$ 的逆时针弧长为 $3\pi/2$ ，顺时针弧长为 $\pi/2$ 。两条匀速圆弧都满足零协变加速度，只有后者达到距离。初值方程根据起点和初速度延伸一条路径，并不比较不同初速度生成的路线谁更短。割点研究从某点出发的测地线何时失去最短性，共轭点涉及相邻测地线的聚焦与变分退化；这些进一步判据不在本章展开，不能据术语本身判定一条路径最短。

定理 7.27 Hopf-Rinow 定理的最短路存在性结论 设 $(\mathcal{M}, g)$ 为有限维、连通、无边界的光滑 Riemann 流形。若它关于 d_g 完备，则任意两点之间存在长度最短测地线。此时任意初速度的测地运动也可以延拓到所有实数时间。

这里引用这一定理的存在性结论，不展开完整等价条件及证明。完备性是每个 d_g -Cauchy 序列都在 $\mathcal{M}$ 内收敛；它限制了路径是否能在有限长度内跑到空间缺口。结论保证存在而不保证唯一：球面的对跖点之间有多条最短大圆弧，指数映射仍不是全局单射。紧致无边界的 Riemann 流形满足这里的完备性条件。

穿孔平面给出省略完备性的反例。用欧氏诱导度量连接 $(-1, 0)^T$ 和 $(1, 0)^T$ ，沿横轴走到 $(-\varepsilon, 0)^T$ ，绕半径 ε 的半圆，再沿横轴到终点，长度为

$$(1 - \varepsilon) + \pi\varepsilon + (1 - \varepsilon) = 2 + (\pi - 2)\varepsilon \longrightarrow 2.$$

环境距离给出下界 2，所以 $d_g = 2$ 。长度等于端点欧氏距离的路径只能沿连接线段前进，该线段经过被删去的原点，故没有允许路径达到下确界。这里仍有局部测地解，却没有这两个端点的最短路。

7.4.4 局部路径比较与曲率

球面闭路例子已经表明，搬运结果可以依赖路线。为检测一个点附近的这种差异，可以比较沿两个方向先后求协变导数的结果。方向场本身未必可交换，必须扣除 $[U, V]$ 造成的变化，剩下的才是联络对局部路径差异的响应。这里有三个方向的不同职责： U, V 指定小回路的两个方向，另一个切向量 W 是沿路搬运的箭头。给定前两个方向后，曲率作用在 W 上，检测绕路带来的方向变化； W 不必等于路径的前进速度。

定义 7.28 Riemann 曲率 本章取曲率符号约定

$$R(U, V)W = \nabla_U \nabla_V W - \nabla_V \nabla_U W - \nabla_{[U, V]} W. \quad (7.41)$$

Levi-Civita 联络的这个算子称为 Riemann 曲率 (Riemann curvature)。在点 p 处, 其值只依赖 U, V, W 在该点的值, 而不依赖它们在附近的具体延拓。

最后一项消掉方向场选择带来的导数项, 使 R 成为按点定义的张量。例如在 V 前乘光滑函数时, 前两项会出现关于该函数的导数, 第三项恰好抵消它们。小闭路搬运相对于恒等映射的首个非零变化由 $R(u, v)$ 乘闭路面积尺度控制; 具体正负随绕行方向约定改变。有限大闭路的总效应不能简单用某一点的曲率乘面积代替。

曲率算子仍含多个方向。选定一个二维切平面, 可以用它给出一个标量曲率, 比较该平面内的局部几何。

定义 7.29 截面曲率 若 $u, v \in T_p \mathcal{M}$ 线性无关, 定义它们张成平面的截面曲率 (sectional curvature) 为

$$K_p(u, v) = \frac{g(R(u, v)v, u)}{g(u, u)g(v, v) - g(u, v)^2}. \quad (7.42)$$

分母是该平行四边形的平面积, 正定性保证它为正值。

更换同一平面的基不改变比值。二维流形每点只有整个切平面这个选择, 所得量就是 Gauss 曲率; 一维流形没有二维切平面, 不能给圆硬套一个截面曲率数值。一维 Riemann 曲率张量恒为零。

平面采用欧氏度量时, 直角坐标中的联络系数为零, 故 $R = 0$ 。半径 R_0 的圆柱取局部参数 $(s, z) \mapsto (R_0 \cos(s/R_0), R_0 \sin(s/R_0), z)$, 诱导度量为 $ds^2 + dz^2$, 所以局部联络系数和内在曲率同样为零。圆柱在环境中明显弯曲, 却可以局部无伸缩地展开成平面; 把圆柱卷起来改变的是嵌入形状, 不是这个局部度量。

半径 R_0 的球面则不同。对切向场, 微分 $\langle V, p \rangle = 0$ 给出 $\langle dV(U), p \rangle = -\langle V, U \rangle$, 因此

$$\nabla_U V = dV(U) + \frac{g(U, V)}{R_0^2} p.$$

将其代入曲率定义, 环境二阶导数与交换子相消; 再投影时, 法向系数的导数被消去, 而 $d p(U) = U$ 留下

$$R(U, V)W = \frac{1}{R_0^2} (g(V, W)U - g(U, W)V).$$

代入式 (7.42) 便得任意截面 $K = 1/R_0^2 > 0$ 。这也核对了本章曲率符号：球面的曲率为正。

在图 7.5 所用的单位球面北极 $N = (0, 0, 1)^\top$ ，取正交单位切向量 $\mathbf{u} = \mathbf{e}_x$ 、 $\mathbf{v} = \mathbf{e}_y$ 。若被搬运的箭头取 $\mathbf{W} = \mathbf{v}$ ，上式具体给出

$$R(\mathbf{u}, \mathbf{v})\mathbf{v} = \mathbf{u}, \quad K_N(\mathbf{u}, \mathbf{v}) = \frac{g(\mathbf{u}, \mathbf{u})}{1 \cdot 1 - 0^2} = 1.$$

分子读出曲率作用后沿 $\mathbf{u}$ 的分量，分母消去所选两方向围成的面积平方的尺度。这里计算北极处切平面的局部曲率；前面的三段球面图则计算绕完整条闭路后的方向。两者的联系要通过缩小闭路来观察：回路足够小时，方向变化的首项才由该处曲率与面积尺度决定。

现在可回看局部 PCA 的法向误差。圆的一维方向沿环境空间转动，产生二阶法向偏离，但其内在 Riemann 曲率为零；圆柱也有法向弯曲而内在平坦。二维开带本来就是平面的开集，式 (7.29) 虽有随位置变化的系数，内在曲率仍为零。这些例子说明，法向二阶误差和 Christoffel 系数都不能单独作为内在非零曲率的证据。局部曲率也不替代拓扑：平面与圆柱局部同样平坦，整体的环却不同；局部零曲率本身不保证任意全局闭路上的搬运都平凡。

7.5 流形上的优化

几何结构确定以后，还要区分求解对象。在球面上找一个使损失最小的点，未知量是有限维流形中的位置；给球面上每个位置分配一个平滑函数值，未知量则是整个函数。前者在当前切空间中选方向，后者要允许整幅函数同时变化。二者都使用度量，却使用不同的优化空间与梯度。

7.5.1 流形点的优化

考虑 $\min_{\mathbf{p} \in \mathcal{M}} f(\mathbf{p})$ ，其中 f 为至少二阶连续可微的实函数。流形约束已经包含在可行域中。普通偏导给出坐标变化，但实际可行的一阶变化属于 $T_{\mathbf{p}}\mathcal{M}$ ；有限步更新还必须从切空间返回流形。

7.5.1.1 流形约束下的最优性条件

存在性与求解方法应分开。若非空流形 $\mathcal{M}$ 紧致且 f 连续，极小值定理保证全局最小值存在；在非紧空间上，可以改为要求某个非空下水平集 $\{\mathbf{p} : f(\mathbf{p}) \leq c\}$ 紧致；不能只凭可微性保证存在。局部极小只和附近可行点比较，全局极小则和全部可行点比较。以下最优性条件用于无边界流形上的点；若还施加不等式约束，其取等位置需要另外检查约束允许的方向。

微分 df_p 已在局部线性化中定义为对切向量的线性读取。要从这个读取规则选出最陡方向，还需用度量把它表示成向量。

定义 7.30 Riemann 梯度 给定光滑函数 f ，点 p 处的 Riemann 梯度 (Riemannian gradient) 是由下式唯一确定的切向量 $\text{grad } f(p)$:

$$g_p(\text{grad } f, v) = df_p(v) \quad (v \in T_p \mathcal{M}) \quad (7.43)$$

有限维内积的正定性保证存在唯一的表示向量。微分由 f 决定，梯度还依赖度量；改变度量会改变最陡方向，但不改变微分是否为零。由 Cauchy-Schwarz 不等式，在 $\|v\|_g = 1$ 的方向中， $df(v)$ 最小为 $-\|\text{grad } f\|_g$ ，非驻点时在负梯度的单位方向达到。

设 $\hat{f} = f \circ \varphi$ 为坐标表达，为简洁把其偏导列表写作

$$\nabla_z f = (\partial_1 \hat{f}, \dots, \partial_d \hat{f})^\top.$$

若梯度坐标为 a ，则对所有坐标向量 v 有 $a^\top G v = \nabla_z f^\top v$ ，所以

$$[\text{grad } f]_z = G^{-1} \nabla_z f. \quad (7.44)$$

偏导列表记录的是各个坐标变化引起的函数值变化，也就是微分的分量。逆度量再把这些分量转成梯度的切向量分量；只有特定正交归一坐标中二者分量相同。对欧氏诱导度量，若 f 有环境光滑延拓 $\bar{f}$ ，则 $\text{grad } f(p) = P_p \nabla \bar{f}(p)$ ，因为投影不改变与任一切向量的内积。

不同位置的梯度分别属于各自的切空间。要研究梯度怎样变化，先要用联络比较这些向量，才能得到流形上的二阶信息。

定义 7.31 Riemann Hessian 在 Levi-Civita 联络下，定义 Riemann Hessian (Riemannian Hessian) 为线性算子

$$\text{Hess } f(p)[v] = \nabla_v \text{grad } f \quad \text{从 } T_p \mathcal{M} \text{ 到自身.}$$

其双线性形式为 $\text{Hess } f(u, v) = g(u, \text{Hess } f[v])$ 。

度量相容和无挠使双线性形式对称。具体地，

$$g(\nabla_U \text{grad } f, V) = U(Vf) - (\nabla_U V)f;$$

交换 $\mathbf{U}, \mathbf{V}$ 后的差为 $[\mathbf{U}, \mathbf{V}]f - (\nabla_{\mathbf{U}}\mathbf{V} - \nabla_{\mathbf{V}}\mathbf{U})f = 0$ 。在坐标中双线性形式的矩阵是

$$B_{i,j} = \partial_i \partial_j \hat{f} - \sum_k \Gamma_{i,j}^k \partial_k \hat{f}, \quad [\text{Hess } f]_{\mathbf{z}} = \mathbf{G}^{-1} \mathbf{B}. \quad (7.45)$$

矩阵 $\mathbf{B}$ 对称；线性算子的坐标矩阵 $\mathbf{G}^{-1} \mathbf{B}$ 一般不是普通转置意义的对称矩阵，却相对于内积 $\mathbf{G}$ 自伴。非驻点处不能省略联络修正项。

沿任意 C^2 曲线，对 $f(\gamma(t))$ 再求一次导数可得

$$\frac{d^2}{dt^2} f(\gamma(t)) = g(\text{Hess } f[\dot{\gamma}], \dot{\gamma}) + g(\text{grad } f, D\dot{\gamma}/dt). \quad (7.46)$$

测地线上第二项为零。因此，在无边界的局部极小点 $\mathbf{p}_*$ ，任意初速度的测地线都给出一元局部极小，必要条件为

$$\text{grad } f(\mathbf{p}_*) = \mathbf{0}, \quad g(\text{Hess } f(\mathbf{p}_*)[\mathbf{v}], \mathbf{v}) \geq 0 \quad \text{对所有 } \mathbf{v}.$$

若梯度为零且 Hessian 正定，指数坐标中的二阶 Taylor 展开给出严格局部极小。半正定只给必要性，仍需更高阶信息；梯度为零也可能是极大点或鞍点。

欧氏凸性不能不加条件地移到弯曲可行域，因为连接两点的环境线段未必可行。一种替代条件是测地凸性 (geodesic convexity)：在一个任意两点都可由域内最短测地线连接的区域 Ω 上，若 f 沿每条这样的仿射参数测地线都是一元凸函数，就称其在该区域测地凸。此时对从 $\mathbf{p}$ 到 $\mathbf{q}$ 的此类路径，一元凸性给出 $f(\mathbf{q}) \geq f(\mathbf{p}) + df_{\mathbf{p}}(\dot{\gamma}(0))$ (参数区间取 $[0, 1]$)；故域内驻点是域内全局极小。区域是否具有所需连接性质、函数是否满足沿路凸性，都须验证，不能由“目标来自欧氏凸函数”自动推出。

7.5.1.2 一阶信息下的梯度求解

负梯度是可行的瞬时方向， $\mathbf{p} - \alpha \text{grad } f(\mathbf{p})$ 却通常离开流形。指数映射给出一种更新，但求解精确测地线可能昂贵。如果只需保证一阶变化正确，可以使用更易计算的局部返回映射。

定义 7.32 回缩 对每个 $\mathbf{p}$ ，在 $T_{\mathbf{p}}\mathcal{M}$ 的零向量邻域中给定 $\mathcal{R}_{\mathbf{p}}(\mathbf{v}) \in \mathcal{M}$ ，并使其光滑依赖 $(\mathbf{p}, \mathbf{v})$ 。若

$$\mathcal{R}_{\mathbf{p}}(\mathbf{0}) = \mathbf{p}, \quad d(\mathcal{R}_{\mathbf{p}})_0[\mathbf{v}] = \mathbf{v},$$

则称这一族映射为回缩 (retraction)。

第一项保留起点，第二项保留初速度。它不要求沿 $t \mapsto \mathcal{R}_p(tv)$ 作精确测地运动，也不要求任意大步长都在定义域中。指数映射是一种局部回缩，其他回缩可有不同的高阶误差。

用括号上标记迭代步，梯度更新写成

$$\mathbf{p}^{(k+1)} = \mathcal{R}_{\mathbf{p}^{(k)}}(-\alpha^{(k)} \text{grad } f(\mathbf{p}^{(k)})). \quad (7.47)$$

回缩的一阶相容性保证，沿该搜索曲线在 $\alpha = 0$ 处

$$\left. \frac{d}{d\alpha} f(\mathcal{R}_{\mathbf{p}}(-\alpha \text{grad } f)) \right|_{\alpha=0} = -\|\text{grad } f\|_g^2.$$

因此非驻点处足够小的正步长确实下降。可以在回缩定义域内回溯，检验 $f(\mathbf{p}^{(k+1)}) \leq f(\mathbf{p}^{(k)}) - c\alpha^{(k)}\|\text{grad } f(\mathbf{p}^{(k)})\|_g^2$ ，其中 $0 < c < 1$ 。这只是逐步下降机制；若还要推出梯度范数趋零，通常还要求下水平集紧致、目标有下界，各点的 $f \circ \mathcal{R}_p$ 满足统一的局部光滑界，并采用相应的回溯规则。非凸问题不能因此保证全局极小，梯度范数趋零也不等于迭代点必然收敛。

示例 7.33 球面上的归一化更新 单位球面上 $\mathbf{p}^\top \mathbf{v} = 0$ ，故 $\|\mathbf{p} + \mathbf{v}\|_2 = \sqrt{1 + \|\mathbf{v}\|_2^2}$ 。取

$$\mathcal{R}_p(\mathbf{v}) = \frac{\mathbf{p} + \mathbf{v}}{\sqrt{1 + \|\mathbf{v}\|_2^2}}. \quad (7.48)$$

结果始终在球面上，零点导数为 $\mathbf{v}$ ，所以是回缩。设 $r = \|\mathbf{v}\|_2 > 0$ ，该点沿大圆偏转的角度是 $\arctan r$ ，指数映射则偏转 r 。二者只在小步长下接近，不是同一更新。

例如 $f(\mathbf{p}) = -\mathbf{a}^\top \mathbf{p}$ 、 $\mathbf{a} \neq \mathbf{0}$ ，有 $\text{grad } f = -\mathbf{a} + (\mathbf{a}^\top \mathbf{p})\mathbf{p}$ 。负梯度从 $\mathbf{a}$ 中去掉法向分量 $(\mathbf{a}^\top \mathbf{p})\mathbf{p}$ ，得到当前可行的切向方向；沿它走有限一步后，归一化再将结果送回球面。驻点为 $\pm \mathbf{a} / \|\mathbf{a}\|_2$ ；在切空间上 $\text{Hess } f[\mathbf{v}] = (\mathbf{a}^\top \mathbf{p})\mathbf{v}$ ，故正向驻点是严格极小，反向驻点是严格极大。单独检验梯度为零无法区分二者。

图 7.6 固定同一个切向步，比较指数映射和归一化回缩。两种更新都可，但沿大圆走过的角度不同。




图 7.6 单位圆截面中的切向步、指数映射与归一化回缩。取 $\mathbf{p} = (1, 0)^\top$ 、 $\mathbf{v} = (0, 1.1)^\top$ 。黄色箭头为切向步，终点 $\mathbf{p} + \mathbf{v}$ 位于圆外；红色径向箭头将该点归一化为 $\mathcal{R}_p(\mathbf{v})$ 。从起点方向计，蓝色指数更新转过 1.1 弧度，归一化回缩转过 $\arctan(1.1) \approx 0.833$ 弧度。两种更新关于步长的曲线在零步长处有相同初速度，但有限步位置不同。图为解析教学示例。

7.5.1.3 二阶信息下的 Newton 与信赖域求解

只看梯度，还不知道沿某个方向走多远才合适。加入 Hessian 后，可以用二次模型预测当前点附近的函数值，再据此选择步长和方向。在 $\mathbf{p}$ 的切空间建立模型

$$m_p(\boldsymbol{\eta}) = f(\mathbf{p}) + g(\text{grad } f, \boldsymbol{\eta}) + \frac{1}{2}g(\boldsymbol{\eta}, \text{Hess } f[\boldsymbol{\eta}]).$$

Newton 方向解 $\text{Hess } f[\boldsymbol{\eta}] = -\text{grad } f$ ，再用 $\mathcal{R}_p(\alpha \boldsymbol{\eta})$ 更新。取切空间的正交归一基后，这个 Newton 方程成为对称线性系统，可用上一章的方法求解；一般坐标中可用式 (7.45) 写成 $\mathbf{B}\boldsymbol{\eta} = -\nabla_{\mathbf{z}} f$ 。Hessian 奇异时方向可能不存在或不唯一，不定时 Newton 方向也可能不是下降方向。局部快速收敛需要非退化解、足够光滑性、合适回缩和足够近的初始点，不是二阶公式本身提供的全局保证。

信赖域方法限制模型适用范围，在 $\|\boldsymbol{\eta}\|_g \leq \Delta$ 中近似最小化 m_p 。用实际下降与预测下降之比

$$\rho = \frac{f(\mathbf{p}) - f(\mathcal{R}_p(\boldsymbol{\eta}))}{m_p(\mathbf{0}) - m_p(\boldsymbol{\eta})}$$

判断接受步和调整 Δ ，只在分母为正时使用这个比值。它允许利用负曲率方向，同时避免把远离当前点的模型误当成目标本身。收敛结论仍需模型误差控制、子问题下降量及更新规则。

前面的二次模型按流形 Hessian 预测函数值，实际更新却使用回缩。要把预测下降与真实下降相比较，还须检查回缩曲线的二阶变化是否与模型一致。令拉回目标 $\hat{f}_{\mathbf{p}}(\boldsymbol{\eta}) = f(\mathcal{R}_{\mathbf{p}}(\boldsymbol{\eta}))$ ，它定义在固定向量空间 $T_{\mathbf{p}}\mathcal{M}$ 上。回缩只保证其零点一阶导数等于 $df_{\mathbf{p}}$ 。设 $c(t) = \mathcal{R}_{\mathbf{p}}(t\boldsymbol{\eta})$ ，由式 (7.46)，

$$\left. \frac{d^2}{dt^2} \hat{f}_{\mathbf{p}}(t\boldsymbol{\eta}) \right|_{t=0} = g(\boldsymbol{\eta}, \text{Hess } f[\boldsymbol{\eta}]) + g(\text{grad } f, D\dot{c}/dt|_{t=0}). \quad (7.49)$$

若回缩对所有 $\boldsymbol{\eta}$ 均满足 $D\dot{c}/dt|_0 = \mathbf{0}$ ，称为二阶回缩 (second-order retraction)。此时，或当前点已经驻定时，额外项才必定消失，拉回目标的零点 Hessian 才与 Riemann Hessian 一致。指数映射满足该条件；球面归一化回缩也满足，因为 $c''(0) = -\|\boldsymbol{\eta}\|_2^2 \mathbf{p}$ 为纯法向。对任意一阶回缩直接作二阶等同则不成立，必须修正模型或另外证明所用模型满足算法的误差要求。这些模型条件及一阶、二阶算法的收敛分析可参见 Boumal 的教材³。

³ N. Boumal, *An Introduction to Optimization on Smooth Manifolds*, Cambridge University Press, 2023

若还要复用前一步的动量或搜索方向，就会再次遇到跨点比较：旧方向属于旧位置的切空间，必须先搬到新切空间，才能与当前梯度相加。可以沿已选路径作平行移动，也可指定较便宜的向量搬运 (vector transport) $\mathcal{T}_{\boldsymbol{\eta}} : T_{\mathbf{p}}\mathcal{M} \rightarrow T_{\mathcal{R}_{\mathbf{p}}(\boldsymbol{\eta})}\mathcal{M}$ ，要求其对被搬运向量线性、随变量光滑且零步长时为恒等映射。例如嵌入流形可投影旧方向到新切空间；这一般不保长度，甚至可能压掉某些方向，并不是 Levi-Civita 平行移动。采用哪种搬运及它保留什么性质，必须与具体迭代方法一起说明。

7.5.2 流形上函数与向量场的优化

现在不再移动一个点，而是在固定流形上调整整个函数 f 或向量场 $\mathbf{V}$ 。例如，我们只在点带的一些位置测得标量值，希望补全其他位置的数值，并避免相邻位置的数值剧烈变化。此时每点的切向梯度仍用来测量空间变化，但一次优化要修改许多位置的函数值，所以优化方向本身是一个函数；调整方向场时，优化方向则是一个向量场。

7.5.2.1 平滑能量与边界条件

相同的函数值差，若发生在更短的几何距离内，变化更剧烈。因此应累计单位长度上的变化，而不是把坐标偏导不加权地平方相加。

定义 7.34 Dirichlet 能量 实函数 f 的 Dirichlet 能量定义为

$$\mathcal{E}(f) = \frac{1}{2} \int_{\mathcal{M}} \|\text{grad } f\|_g^2 dV_g. \quad (7.50)$$

对光滑函数按通常导数理解；积分不有限时取 $+\infty$ 。

度量同时决定梯度和体积。对开带, $\sqrt{\det \mathbf{G}} = 1 + u/R$ 且 $\mathbf{G}^{-1} = \text{diag}((1 + u/R)^{-2}, 1)$, 故

$$\mathcal{E}(f) = \frac{1}{2} \int \left[\frac{(\partial_s f)^2}{1 + u/R} + (1 + u/R)(\partial_u f)^2 \right] ds du. \quad (7.51)$$

外侧相同 ds 更长, 所以相同 $\partial_s f$ 对应较小的单位长度变化; 与此同时, 小坐标盒的实际面积更大。所以纵向导数的权重既要考虑单位长度上的变化, 也要考虑积分区域的面积; 不能只改梯度, 或只改体积元。

仅写能量还没有完整规定问题。以下主要取紧致无边界流形, 或具有分片光滑边界的紧积分域, 并先对足够光滑函数作变分。若还希望接纳导数仅在积分意义下存在、但能量有限的候选函数, 可以使用 $H^1(\mathcal{M})$: 它由函数及其弱一阶导数都平方可积的函数组成, 范数满足

$$\|f\|_{H^1}^2 = \int_{\mathcal{M}} (|f|^2 + \|\text{grad } f\|_g^2) dV_g.$$

弱导数通过分部积分定义, 在光滑函数上与前面的导数一致。这使有限能量但不逐点光滑的极限也可作为候选。若在非紧空间工作, 平方可积性、无穷远行为以及测试函数范围还须另定, 不能自动删去无穷远处的边界贡献。

当前开带不含边界。需要固定边缘数值时, 另取

$$\overline{\mathcal{M}}_{\text{strip}} = \{\Phi(s, u) : s \in [s_-, s_+], |u| \leq w\},$$

沿用原参数式到闭区间的延拓。这是有分片光滑边界的紧积分域; 四个角点的法向虽不唯一, 却是边界测度零集。函数应有相应边界迹。对光滑函数, 可以直接读出边界值; 对弱解, 则把这一读取规则连续延拓到所用函数空间, 按算子意义确定边界迹。若预先固定边界值, 允许的扰动就不能改变这些值, 因此扰动的边界迹必须为零。若边界值也可调整, 则要把边界扰动纳入变分, 由驻定条件决定自然边界条件。

在紧域上, 不加限制时常量函数已经取得 $\mathcal{E} = 0$, 所以“最平滑”不会自动保留观测信号。可以规定边界值, 加入数据拟合积分 $\frac{\lambda}{2} \int |f - y|^2 dV_g$, 或施加均值与范数约束。例如零均值加单位 L^2 范数排除常量, 并将问题连到非平凡谱模态。使用 H^1 时还要检查数据怎样读取函数。一般维数下, 指定一个点的函数值未必能被唯一、稳定地读取; 要拟合逐点观测, 就需更高的正则性, 或者改为拟合观测位置附近的局部平均。

向量场的平滑要先比较不同点的方向, 故使用协变导数。取局部正交归一切基 $\mathbf{e}_1, \dots, \mathbf{e}_d$, 定义

$$\|\nabla \mathbf{V}\|_g^2 = \sum_{a=1}^d \|\nabla_{\mathbf{e}_a} \mathbf{V}\|_g^2, \quad \mathcal{E}_{\nabla}(\mathbf{V}) = \frac{1}{2} \int_{\mathcal{M}} \|\nabla \mathbf{V}\|_g^2 dV_g.$$

正交换基不改变这个平方和, 所以定义与局部基选择无关。有限能量空间可相应要求 $\mathbf{V}$ 及 $\nabla \mathbf{V}$ 平方可积, 边界迹、观测或归一化限制也应针对向量场重新规定。坐标分量恒定的场未必平行, 环境恒定向量也未必处处切向; 向量场不能用“不变的逐坐标数值”代替零协变变化。

7.5.2.2 能量变分与连续求解

取允许扰动 h , 令 $f_\epsilon = f + \epsilon h$ 。梯度对函数线性, 对平方范数求导得到

$$\left. \frac{d}{d\epsilon} \mathcal{E}(f + \epsilon h) \right|_{\epsilon=0} = \int_{\mathcal{M}} g(\text{grad } f, \text{grad } h) dV_g. \quad (7.52)$$

这里扰动的是各位置的函数值, 而不是移动流形上的一个点。要像有限维优化那样从一阶变分读出优化方向, 需要把右侧改写成某个函数与 h 的内积, 这就要求通过分部积分移去 h 上的空间导数。

令 $J_g = \sqrt{\det \mathbf{G}}$ 。光滑向量场 $\mathbf{V} = \sum_i V^i \partial_i$ 的散度为

$$\text{div}_g \mathbf{V} = \frac{1}{J_g} \sum_i \partial_i (J_g V^i).$$

它测量相对于几何体积的局部净流出: 对坐标小区域作普通分部积分时, J_g 正是体积密度, 故不能只保留 $\sum_i \partial_i V^i$ 。其散度定理为 $\int_{\mathcal{M}} \text{div}_g \mathbf{V} dV_g = \int_{\partial \mathcal{M}} g(\mathbf{V}, \mathbf{n}) dS_g$, 其中 $\mathbf{n}$ 在 $T\mathcal{M}$ 内垂直于边界、指向外侧且为单位长度, dS_g 是诱导边界面积元。

定义 7.35 Laplace–Beltrami 算子 设 f 为二阶连续可微的实函数。将梯度再取散度, 得到 Laplace–Beltrami 算子 (Laplace–Beltrami operator):

$$\Delta_g f = \text{div}_g(\text{grad } f) = \frac{1}{\sqrt{\det \mathbf{G}}} \sum_{i,j} \frac{\partial}{\partial z^i} \left(\sqrt{\det \mathbf{G}} g^{i,j} \frac{\partial f}{\partial z^j} \right). \quad (7.53)$$

本章取 Δ_g 为热方程生成元; 适当边界条件下, $-\Delta_g$ 是非负算子。

它描述相对于当前几何的局部二阶变化。坐标尺度与体积随位置变化时, 公式中的度量权重及其导数也参与计算, 因此一般不能只把各坐标二阶偏导相加。散度的乘积法则给出 $\text{div}_g(h \text{grad } f) = g(\text{grad } h, \text{grad } f) + h \Delta_g f$ 。积分并用散度定理, 得到 Green 恒等式

$$\int_{\mathcal{M}} g(\text{grad } f, \text{grad } h) dV_g = - \int_{\mathcal{M}} h \Delta_g f dV_g + \int_{\partial \mathcal{M}} h \partial_{\mathbf{n}} f dS_g, \quad (7.54)$$

其中 $\partial_{\mathbf{n}} f = g(\text{grad } f, \mathbf{n})$ 。

无边界时没有最后一项。固定 f 的边界迹时, 允许的 h 在边界为零, 这给出 Dirichlet 条件; 边界自由时, 要对任意边界扰动驻定, 就需 $\partial_n f = 0$, 这是自然的齐次 Neumann 条件。对未加数据项的能量, 内部驻点满足 $\Delta_g f = 0$ 。闭带的两条长边和两个端部都需按问题规定条件, 不能只处理图上显眼的一条边。

函数空间也有自己的内积。取 $\langle u, h \rangle_{L^2} = \int_{\mathcal{M}} u h \, dV_g$ 。把 Dirichlet 能量视为 L^2 上的泛函时, 有限值需要 $f \in H^1$; 若固定 Dirichlet 边值, 还需施加相应的迹约束。这不是 L^2 开邻域上的有限值可微泛函: L^2 很小的扰动仍可能具有很大的空间导数, 甚至不属于 H^1 。因此, 不能直接套用定义 5.26 中的 Fréchet 微分与梯度。这里先沿允许的 H^1 扰动求一阶变分, 再判断这个线性读取能否用一个 L^2 函数表示。当 f 属于所选算子的定义域, 即满足该算子的可求导要求与边界条件, 并且 $\Delta_g f \in L^2$ 、边界项消失时, 上式把一阶变分表示为 $\delta \mathcal{E}(f)[h] = \langle -\Delta_g f, h \rangle_{L^2}$ 。这里将这个表示函数称为能量的 L^2 梯度, 即 $\text{grad}_{L^2} \mathcal{E}(f) = -\Delta_g f$; 将允许函数以外的能量扩为 $+\infty$ 后, 也可用相应凸能量的 L^2 次梯度表述这一关系。负梯度流为热方程

$$\frac{\partial f}{\partial t} = \Delta_g f. \quad (7.55)$$

若解足够光滑, 且满足所选的、随时间保持不变的边界条件, 则

$$\frac{d}{dt} \mathcal{E}(f_t) = - \int_{\mathcal{M}} (\Delta_g f_t)^2 \, dV_g \leq 0.$$

热流随时间调整整幅函数, 使它的能量下降。 $\text{grad} f$ 在每个位置给出函数值沿空间变化的切向量; $\text{grad}_{L^2} \mathcal{E}$ 则是一个标量函数, 表示能量对各位置函数值变化的响应, 优化沿它的负方向调整函数值。前者测量空间变化, 后者提供函数优化方向。换用带权 L^2 或 H^1 内积, 表示同一能量微分的梯度会改变, 不能仍无条件使用相同热方程。这里 t 是扩散时间, 不是点带的空间坐标 s 。

能量与谱也由同一恒等式联系。对正维数、紧致、光滑且无边界的 Riemann 流形, $-\Delta_g$ 在 $L^2(\mathcal{M}, dV_g)$ 中有离散谱

$$0 = \lambda_0 \leq \lambda_1 \leq \dots, \quad \lambda_k \longrightarrow \infty,$$

按重数排列, 并有光滑特征函数组成完备正交系。若 $-\Delta_g \phi = \lambda \phi$ 且 $\phi \neq 0$, 取 $h = \phi$ 得到

$$\lambda \int_{\mathcal{M}} \phi^2 \, dV_g = \int_{\mathcal{M}} \|\text{grad} \phi\|_g^2 \, dV_g \geq 0.$$

这证明非负性; 离散性与完备性还使用紧致性和椭圆算子理论, 不由此等式单独推出。零特征函数在每个连通分支上为常量, 连通时零特征空间恰为一维。在有非空边界的连通紧光滑域上, Neumann 条件仍保留常量零

模，齐次 Dirichlet 条件则使首个特征值严格为正；若不是这类域，必须重新核对谱与边界条件，不能仅以“有边界”概括。

示例 7.36 圆上的坐标、能量与谱尺度 半径为 R 的完整圆采用角坐标 θ ， $g_{\theta\theta} = R^2$ 、 $dV_g = R d\theta$ 。取 $f(\theta) = \cos \theta$ ，则

$$\begin{aligned}\|\text{grad } f\|_g^2 &= \frac{\sin^2 \theta}{R^2}, \\ \Delta_g f &= \frac{1}{R^2} f'' = -\frac{\cos \theta}{R^2}, \\ \mathcal{E}(f) &= \frac{1}{2} \int_0^{2\pi} \frac{\sin^2 \theta}{R^2} R d\theta = \frac{\pi}{2R}.\end{aligned}$$

同一幅度变化放在更大的圆上，单位长度上的变化更小；该模态的特征值为 $1/R^2$ ，热流幅度按 $\exp(-t/R^2)$ 衰减。改用局部弧长坐标 $s = R\theta$ 时，度量分量变为 1， $f(s) = \cos(s/R)$ 的导数补入 $1/R$ ，结果不变。能量使用 $1/2$ 归一化，省去它时能量及其梯度都要同步加倍。

向量场能量按相同思路变分，但导数换成协变导数。对允许的扰动场 $\mathbf{W}$ ，

$$\delta \mathcal{E}_V(\mathbf{V})[\mathbf{W}] = \int_{\mathcal{M}} \sum_a g(\nabla_{\mathbf{e}_a} \mathbf{V}, \nabla_{\mathbf{e}_a} \mathbf{W}) dV_g.$$

对每个求导方向作度量相容的分部积分，得到

$$\delta \mathcal{E}_V(\mathbf{V})[\mathbf{W}] = \int_{\mathcal{M}} g(\nabla^* \nabla \mathbf{V}, \mathbf{W}) dV_g + \int_{\partial \mathcal{M}} g(\nabla_{\mathbf{n}} \mathbf{V}, \mathbf{W}) dS_g, \quad (7.56)$$

其中 ∇^* 是形式 L^2 伴随：先对光滑、紧支撑的测试场作分部积分，把 ∇ 移到内积另一侧，得到相应的微分表达式。这没有直接套用定义 5.22 中有界算子的伴随定理；作为 L^2 中的微分算子， ∇ 还需要另外规定可求导的定义域。度量、联络和体积元决定形式表达式，函数空间与边界条件则进一步决定实际算子及其 Hilbert 伴随的定义域。算子 $\nabla^* \nabla$ 称为联络拉普拉斯 (connection Laplacian)，本章取非负号约定。在局部正交归一标架中，

$$\nabla^* \nabla \mathbf{V} = - \sum_a \left(\nabla_{\mathbf{e}_a} \nabla_{\mathbf{e}_a} \mathbf{V} - \nabla_{\nabla_{\mathbf{e}_a} \mathbf{e}_a} \mathbf{V} \right).$$

修正项记录标架自身的变化，不能省略。固定向量场边界迹时 $\mathbf{W} = 0$ ；自由边界给出自然条件 $\nabla_{\mathbf{n}} \mathbf{V} = 0$ 。边界项消失后， $\langle \mathbf{V}, \nabla^* \nabla \mathbf{V} \rangle_{L^2} = \int \|\nabla \mathbf{V}\|_g^2 dV_g \geq 0$ ，向量场梯度流为 $\partial_t \mathbf{V} = -\nabla^* \nabla \mathbf{V}$ 。向量场能量为零，要求场在所有方向上的协变导数都为零，也就是处处平行。满足这个条件的非零场未必存在；标量常量零模的结论不能直接移过来，更不能逐坐标照抄标量 Laplace-Beltrami 公式。

7.5.2.3 有限采样下的离散近似

只有点云时，常以近邻函数值差构造离散平滑代价

$$\mathcal{E}_n(f) = \frac{1}{2} \sum_{i,j} w_{i,j} (f_i - f_j)^2.$$

这里约定求和遍历有序点对，取对称非负边权；同一无向边出现两次，其他文献的 $1/2$ 或 $1/4$ 系数需连同边权归一化一起比较。这个形式如何由图拉普拉斯得到，留给第3部分。这里要先判断：这些样本差值的加权和，究竟近似前面的几何能量，还是混入采样密度的另一种能量？

若样本按密度 $q \, dV_g$ 取得，简单样本平均近似 $\int f q \, dV_g$ 而非几何体积积分。求和中的两个样本索引都按采样分布取得，因此双重求和还可能带入两个密度因子。要得到指定的连续能量，必须让边权、邻域宽度、维数相关的缩放和密度修正相互配合；仅仅看到 $(f_i - f_j)^2$ ，还不能判断它的连续极限。例如目标若明确改为 $\mathcal{E}_q(f) = \frac{1}{2} \int q \|\text{grad } f\|_g^2 \, dV_g$ ，在 $q > 0$ 光滑且边界项消失时，分部积分给出

$$\delta \mathcal{E}_q(f)[h] = - \int h \, \text{div}_g(q \, \text{grad } f) \, dV_g.$$

相对于 $L^2(q \, dV_g)$ 内积，其负梯度为 $q^{-1} \text{div}_g(q \, \text{grad } f)$ ，一般不等于 $\Delta_g f$ 。若仍采用 $L^2(dV_g)$ ，负梯度则没有前面的 q^{-1} 。能量权重与求梯度的内积都要明确。

离散时，代表局部体积的质量权重也影响函数空间内积，从而影响由同一离散能量得到的演化算子。非负边权保证离散能量非负， $w_{i,j} = w_{j,i}$ 则使两个方向使用同一权重；但这些代数性质还不能说明由它得到的算子逼近指定的 Laplace–Beltrami 算子。至少还要核对流形正则性、采样覆盖与密度、邻域随样本量缩小的速率、噪声相对尺度的大小，以及边界附近邻域被截断后的处理。固定边界值与无通量条件并不由同一套未加说明的边规则自动实现。

向量场离散还要给出跨点比较。设 $V_i \in T_{p_i} \mathcal{M}$ ，对每条邻边选定 $P_{i \leftarrow j} : T_{p_j} \mathcal{M} \rightarrow T_{p_i} \mathcal{M}$ ，才可形成

$$\mathcal{E}_{n,\nabla}(V) = \frac{1}{2} \sum_{i,j} w_{i,j} \|V_i - P_{i \leftarrow j} V_j\|_{g_{p_i}}^2.$$

若取短测地路径的平行移动，需确保相应路径已选定；处在凸正规邻域内时有唯一的局部选择。若只估计了切平面，可用局部对齐近似，但须分析方向估计及搬运误差。若搬运保持长度，且反向搬运是正向的逆映射，把两个向量放在边的哪一端比较，得到的误差就一致；普通环境投影未必具

备这些性质。非负离散能量同样不自动保证连续联络拉普拉斯的一致近似。

7.6 本章小结

本章开头的圆上更新问题需要的不只是一组新坐标。流形与坐标图说明怎样记录局部位置，切空间和映射微分说明允许的一阶变化；度量再把同点方向转为长度，沿路径累计标量速度，并通过全部允许路径定义端点距离。这条顺序不需要提前搬运向量，也不保证距离下确界一定由某条路径达到。

跨点比较另需联络。平行移动在给定路径上求向量，测地运动则让路径自己的速度平行，初值方程和固定端点最短路因而相关但不等价。曲率描述局部路径比较的差异；环境中的弯曲、坐标系数的变化和整体的环，都不能单独代替内在曲率。圆柱局部平坦而整体有环，圆在环境中弯曲而没有二维截面，二维开带和一维中心线又有不同的可行路径与距离。

优化必须说明未知量。点优化在当前切空间使用梯度和 Hessian，再经指数映射或回缩得到可行点；回缩的一阶相容不自动给出二阶模型相容。函数与向量场优化累计整个空间的变化，由能量、边界条件和函数空间内积共同确定 Laplace–Beltrami 算子或联络拉普拉斯。有限样本上的谱、最短边路径和离散平滑目标，都还要验证采样、尺度、密度与噪声条件。

有限距离重构、对称响应和拓扑表示补充了这些局部工具的边界。保距坐标不自动揭示潜在流形，不变表示会有意舍弃轨道内信息，成对邻接也不能判断高阶填充。使用这些工具时，应先明确研究的是哪一个对象、允许怎样变换和运动。连续模型规定的性质、有限样本中的近似结果和算法输出各自需要不同的依据，这样才能判断几何假设是否适用于当前任务。本章已多次区分几何体积与采样权重，但尚未系统说明随机观测怎样产生、有限样本允许作出什么推断。第 10 章“随机变量”将为这些问题建立分布、条件信息和推断误差的语言。

第三部分

图与信号

Graphs and Signals



阅读指引

本部分研究两类带结构的数据：图用顶点和连接表示对象之间的关系，信号则记录各个时间或位置上的数值。二者都要回答怎样表示、怎样计算以及变换后保留了什么信息，图的连接说明哪些对象相连，信号的数值说明各位置记录了什么。

第 8 章“信号的表示与计算”研究信号的基、频率表示、卷积与相关、快速变换、采样和恢复，并明确有限记录、离散实现与连续模型之间的边界。第 9 章“图的表示与计算”建立图、路径、连通、分离和结构分解，讨论遍历、最短路、生成树、匹配、割、谱方法及图上的传播。

图章关注关系怎样限制可达路径和组合选择，信号章关注数值怎样分解、变换与重构。图上的函数把两类对象连接起来：图决定允许比较哪些位置，函数值承载要传播或滤波的信息。

信号的表示与计算

一段传感器记录既可以按时间逐项读取，也可以分解成不同频率的波动。两种表示描述同一条信号，却适合回答不同问题。按时间看，容易找到变化发生的位置；按频率看，容易判断哪些振荡最强，以及滤波会削弱哪些分量。若只保留部分样本，我们还要判断能否恢复原来的变化。因此需要分清三件事：换一组完整坐标不一定丢失信息，滤波会改变信号，而采样会改变可用的观测。计算某种表示很快，也不能代替对信息是否保留的判断。

本章用两个有限记录作为贯穿示例：

$$\mathbf{x} = (1, 2, 1), \quad \mathbf{h} = (1, -1) \quad (8.1)$$

我们将用它们说明位置、边界、卷积与相关；需要非对称波形或连续时间时，再明确另一个输入。要比较信号，先把信号看成带索引的函数，再用内积和范数衡量它们的差异与大小。要知道一个位置或一种振荡对整条信号贡献了多少，则分别用脉冲或复指数展开。把位置写成多项式的幂次，还能卷积计算提供另一种表示。随后讨论输入怎样经过一个映射变成输出，以及采样以后还能恢复哪些信息。一般函数空间与线性坐标的背景可回查第 5 章和第 6 章。本章着重利用规则时间或位置索引；下一章再把位置之间的关系推广为一般图，比较规则平移与图上传播的区别。至于怎样用内部状态产生输入输出响应，留给第 13 章。

8.1 信号的对象与结构

“三个数”还不是完整的信号说明。它们可能是三个时刻的温度，也可能是同一时刻三个传感器的读数；数组首尾可能互不相连，也可能代表一个周期。在比较大小或选择表示以前，需要先确定索引、取值和边界分别表示什么。

8.1.1 信号的索引与取值

8.1.1.1 连续、离散与有限信号

信号 (signal) 是定义在某个时间或位置索引集上的函数, 函数值记录对应位置的量。连续时间信号写成 $x(t)$, 离散时间信号写成 $x[k]$; 这里的“连续”描述索引, 不要求函数值随时间连续。例如发生突跳的开关读数仍是连续时间信号。

定义 8.1 信号的索引类型 连续时间标量信号是 $x: I \rightarrow \mathbb{F}$, 其中 $I \subseteq \mathbb{R}$ 为时间区间, $\mathbb{F}$ 取 $\mathbb{R}$ 或 $\mathbb{C}$ 。离散时间信号 (discrete-time signal) 是 $x: \mathbb{Z} \rightarrow \mathbb{F}$, 或定义在明确指定的整数子集上。长度 N 的有限信号是 $x: \{0, \dots, N-1\} \rightarrow \mathbb{F}$, 可按位置写成 $\mathbf{x} \in \mathbb{F}^N$ 。

数组下标只是位置编号。若第 k 项来自时刻 $t_0 + kT_s$, 还要给出起点 t_0 及间隔 T_s , 才能把每隔几个样本重复一次的振荡换算成物理频率。不等间隔观测则需要显式保存每个时间戳, 不能直接套用均匀采样公式。二维图像以两个整数坐标标位置, 规则网格上的运算可以相应推广到 $\mathbb{Z}^d$, 但一般图节点的编号不自带这种平移结构。

有序信号与无序样本集合也不同。 $(1, 2, 1)$ 和 $(1, 1, 2)$ 有同样的取值及重数, 相邻变化却不同, 因此局部差分或模板比较可以区分它们。随机信号则是在概率空间上给每个索引配一个随机变量; 固定一次随机结果 ω_0 后, $k \mapsto X_k(\omega_0)$ 成为一条确定路径。对这条路径求频谱与对随机信号求期望是不同操作, 一条实现路径上的规律未必代表所有随机结果的平均规律。本章先研究给定的确定信号, 随机变量、过程及期望在第10章建立后再用于随机信号。

复数值常用来同时记录两个实分量或表示振荡的幅度与相位。记 $i^2 = -1$, 对 $z = a + ib$ 有 $\bar{z} = a - ib$ 、 $|z|^2 = z\bar{z} = a^2 + b^2$ 。这里的复共轭 (complex conjugate) 只改变虚部符号, 不是时间反转; 后文计算信号与自身的内积时, 正是借助共轭, 才得到幅值平方这样的非负量。

8.1.1.2 单通道与多通道信号

立体声在同一时刻有左右两路读数。将两路首尾接起来会把通道差别误当成时间先后, 因此需要分别记录这两种索引。

定义 8.2 标量信号与向量值信号 单通道信号在每个位置取一个标量值。 d 通道信号在每个位置取向量值 $\mathbf{x}[k] = (x_1[k], \dots, x_d[k])^\top \in \mathbb{F}^d$; 连续时间时相应写作 $\mathbf{x}(t)$ 。 N 个位置的记录可写为 $\mathbf{X} \in \mathbb{F}^{N \times d}$, 约定 $\mathbf{X}_{k+1,c} = x_c[k]$, 其中 $k = 0, \dots, N-1$ 、 $c = 1, \dots, d$ 。

时间轴长度为 N ，通道数为 d ，两者不互换。比如

$$\mathbf{X} = \begin{bmatrix} 1 & 0 \\ 2 & 1 \\ 1 & 2 \end{bmatrix} \quad (8.2)$$

有三个时刻、两个通道；第二行 (2,1) 是同一时刻的联合读数。把两个传感器放在同一个向量里，隐含它们已经按同一时间基准对齐；若第二通道延迟一个采样间隔，应先保留这一偏移，不能把不同时刻的值当作同时观测。多通道既不意味着通道独立，也不意味着必须逐通道处理：可以对每一列分别滤波，也可以在每个时刻以矩阵混合多个通道。第 8.3.2 节将说明这种混合怎样改变通道，以及它是否还使用其他时刻的读数。

8.1.2 信号的周期与边界

8.1.2.1 周期信号与非周期信号

重复观察到相似波形不等于已经证明周期性。周期要求整个定义域上的精确重复，还要求每次平移都留在允许的索引内。

定义 8.3 周期及基本周期 定义在 $\mathbb{R}$ 上的信号 x 若存在 $T > 0$ 使 $x(t+T) = x(t)$ 对所有 t 成立，则称其为周期信号， T 为一个周期。定义在 $\mathbb{Z}$ 上的信号若存在正整数 N 使 $x[k+N] = x[k]$ 对所有整数 k 成立，则称其为周期序列。若正周期中存在最小者，才称其为基本周期。没有正周期的信号称为非周期信号。

在按几乎处处相等识别函数的空间中，周期等式也按几乎处理解。常数连续信号的每个正实数都是周期，却没有最小正周期；离散周期的候选是正整数，非空时一定有最小者。连续复指数 $e^{i\Omega t}$ 在 $\Omega \neq 0$ 时有基本周期 $2\pi/|\Omega|$ ；离散复指数 $e^{i\omega k}$ 则要求 $e^{i\omega N} = 1$ ，即 $\omega/(2\pi)$ 为有理数，才有整数周期。所以连续振荡取样后是否周期还取决于取样间隔与振荡周期的比例。

多通道周期要求所有通道具有一个共同周期。例如

$$\mathbf{x}(t) = \begin{pmatrix} \cos t \\ \cos(\sqrt{2}t) \end{pmatrix}$$

的每一分量都周期，但共同周期必须同时满足 $T = 2\pi m$ 和 $\sqrt{2}T = 2\pi n$ ，其中 m, n 为整数；无理数 $\sqrt{2}$ 使正 T 不可能存在。离散的有限多个周期通道则可取各整数周期的最小公倍数作为共同周期。

还应区分三个对象：物理信号本来周期，有限数组被人为周期延拓，以及变换所得频谱以某个频率间隔重复。后文的离散傅里叶变换（DFT）可以给任意有限数组配置循环索引，不要求记录前后的真实过程恰好重复；离散时间傅里叶变换（DTFT）的频率周期来自整数时间索引，也不要求原序列周期。后文提到首尾回绕时，需要据此判断是时间位置按周期连接，还是频率坐标按周期重复。

8.1.2.2 有限支撑与边界延拓

有限记录只说明观测范围。为了计算跨过首尾的运算，还必须说明区间外采用什么值。离散信号的支撑是 $\{k : x[k] \neq 0\}$ ；只有有限个非零位置时称为有限支撑。连续信号通常以非零集合的闭包定义支撑， L^p 类中使用忽略零测差别的本质支撑。连续时间的有限支撑在此指支撑包含于某个有界区间，不是只有有限个非零点。

对 $x[0], \dots, x[N-1]$ ，零延拓令区间外的值为零；周期延拓令 $x[k] = x[k \bmod N]$ ；反射延拓则把边界附近的值镜像放到区间外。反射有不同端点约定。例如不重复端点且 $N \geq 2$ 时， $x[-1] = x[1]$ 、 $x[N] = x[N-2]$ ，再以 $2(N-1)$ 为周期延续；若重复端点，就有 $x[-1] = x[0]$ 、 $x[N] = x[N-1]$ ，得到另一个延拓。两种方式都可能合理，但不是同一个输入。

贯穿例 (1, 2, 1) 零延拓后，左边相邻值为 0；周期延拓时为 1；不重复端点的反射延拓时为 2。在位置 0 计算当前值减前值，三者分别得到 1, 0, -1。因此，边界规则会直接改变差分的结果。应先确定边界规则，再选择计算方法。

输出裁剪又是另一项选择：先按给定延拓计算输出，再只保留指定位置。裁去首尾不等于改变输入延拓，保持输出长度也不能唯一决定左右怎样补值。周期索引上的运算只在一个周期内计数；若把两条周期延拓序列直接在整轴上无穷求和，同一个贡献会重复无穷次。这一边界将在循环卷积的定义中保留。

8.1.3 信号的比较与大小

8.1.3.1 基于内积的信号比较

判断两个记录是否接近，需要决定哪些位置和通道参与比较。第 5 章使用实内积；本章扩展到复信号时采用第一变量线性、第二变量取共轭的约定。它与第 6.1.3 节的复坐标约定互为共轭，实信号时两者相同；范数与正交性

不变，读取展开系数时却要相应调整内积的顺序。对有限记录、平方可和序列与平方可积函数，分别有

$$\begin{aligned}\langle x, z \rangle_N &= \sum_{k=0}^{N-1} x[k] \overline{z[k]}, \\ \langle x, z \rangle_{\ell_2} &= \sum_{k \in \mathbb{Z}} x[k] \overline{z[k]}, \\ \langle x, z \rangle_{L^2} &= \int_{\mathbb{R}} x(t) \overline{z(t)} dt.\end{aligned}\tag{8.3}$$

后两式的乘积由 Cauchy-Schwarz 不等式保证绝对可和或绝对可积。内积为零表示按当前的位置范围和通道权重比较时，两条信号正交；相应距离为 $\|x - z\|_2$ 。非零信号的归一化比较量 $\rho(x, z) = \langle x, z \rangle / (\|x\|_2 \|z\|_2)$ 满足 $|\rho| \leq 1$ ；实信号时这是夹角余弦，复信号时它一般是复数，包含相对相位。零信号没有这种归一化相似性，不能直接除以零。

例如 $x = (1, 2, 1)$ 、 $z = (1, 0, -1)$ 满足 $\langle x, z \rangle = 0$ ，但两者在位置 0 都有非零值。这里正交是各位置乘积相加后得到零，不要求两个信号在不同位置取非零值。若把 x 变成 $2x$ ，归一化相似性仍为 1，距离却为 $\|x\|_2$ ；这说明方向相同与数值接近是两个判断。

多通道内积同时汇总位置与通道：

$$\langle \mathbf{x}, \mathbf{z} \rangle = \sum_k \sum_{c=1}^d x_c[k] \overline{z_c[k]}.$$

如果不同传感器的单位或重要性不同，可明确选正权重 w_c ，把每项乘以 w_c 。更一般地，Hermitian 正定矩阵 $\mathbf{W}$ 给出 $\sum_k \mathbf{z}[k]^* \mathbf{W} \mathbf{x}[k]$ ，其中 $*$ 表示共轭转置。正定性使非零信号的自内积为正；仅半正定时某些非零通道组合可能被忽略。改变权重可能改变正交关系及相似性排序，因此权重是比较规则的一部分，不能在解释结果时忽略。

8.1.3.2 基于范数的信号大小

衡量信号大小时，可以问峰值有多大，也可以把全部位置的幅值累计起来。累计幅值平方时，大幅值比小幅值占更大的权重。这几种问题分别对应不同范数。对离散标量信号，相应范数是

$$\|x\|_{\infty} = \sup_k |x[k]|, \quad \|x\|_1 = \sum_k |x[k]|, \quad \|x\|_2 = \left(\sum_k |x[k]|^2 \right)^{1/2}.$$

在有限记录上求和只取记录范围；整轴上则要求相应总和有限。记 $\ell_1(\mathbb{Z})$ 为绝对可和序列空间， $\ell_2(\mathbb{Z})$ 为平方可和序列空间。例如 $x[k] = (k+1)^{-1}$ 在 $k \geq 0$ 时取此值、在 $k < 0$ 时取零，属于 ℓ_2 却不属于 ℓ_1 。所以可以定义能量的信号未必能直接使用绝对收敛的变换或卷积论证。

连续情形将和换成积分, 得到 L^1 与 L^2 范数; L^∞ 采用 $\text{ess sup}_t |x(t)|$, 即忽略零测异常点后的最小本质上界。这不同于最大值: 函数可能只趋近其上界而未取到, 也可能在单个点被赋任意大值, 但代表同一个 L^∞ 元素。实际采样却要读取某个具体位置的数值, 因此还要说明从这个等价类中选用哪一个函数。

对贯穿有限记录, $\|x\|_\infty = 2$ 、 $\|x\|_1 = 4$ 、 $\|x\|_2 = \sqrt{6}$ 。重排位置不改变这三个数, 却可以改变局部波形; 范数不是完整的形状描述。多通道的二范数可按 $\|x\|_2^2 = \sum_k \|x[k]\|_2^2$ 定义, 若使用前述 W , 则改为 $\sum_k x[k]^* W x[k]$ 。比较前须固定通道度量, 不能把不同单位的读数无说明地相加。

8.1.3.3 有限能量与平均功率

持续振荡的幅值可以有界, 但持续时间无限, 平方累计仍会发散。这时需要区分累计了多少与每单位时间平均有多少。

定义 8.4 信号能量与平均功率 离散及连续信号的能量分别为

$$E_x = \sum_{k \in \mathbb{Z}} |x[k]|^2, \quad E_x = \int_{\mathbb{R}} |x(t)|^2 dt.$$

能量有限等价于属于相应的 ℓ_2 或 L^2 空间, 且 $E_x = \|x\|_2^2$ 。长期平均功率在相应极限存在时定义为

$$P_x = \lim_{K \rightarrow \infty} \frac{1}{2K+1} \sum_{k=-K}^K |x[k]|^2,$$

$$P_x = \lim_{R \rightarrow \infty} \frac{1}{2R} \int_{-R}^R |x(t)|^2 dt.$$

这里是以幅值平方定义的信号指标; 若要解释为物理能量或功率, 还需相应单位与系统系数。窗口能量则只在声明的记录窗口求和或积分。贯穿例零延拓后的能量为 6; 若将它按周期 3 延拓, 单周期能量仍为 6, 平均功率却为 $6/3 = 2$, 整轴能量发散。一般周期序列满足 $P_x = N^{-1} \sum_{k=0}^{N-1} |x[k]|^2$, 局部平方可积的 T 周期函数满足 $P_x = T^{-1} \int_0^T |x(t)|^2 dt$ 。两式可由长窗口分成完整周期与长度有界的剩余段得到。

非零正弦 $x(t) = A \cos(\Omega t + \varphi)$ 在 $\Omega \neq 0$ 时, 利用 $\cos^2 u = (1 + \cos 2u)/2$ 得到一个周期的平方积分为 $A^2 T/2$, 故 $P_x = A^2/2$, 而无限多个周期的累计能量为无穷。相反, 有限能量信号的长期平均功率为零, 因为平均的分子不超过总能量, 分母却趋于无穷。非周期有界信号未必有平均功率极限, 例如让取值 0 和 1 的交替时间块各自长到压过此前全部时间, 窗口平均就可能持续在不同水平间变化。

后文 Parseval 关系只是在另一组坐标下计算这里已经定义的能量或周期平均功率。其中出现 N 、 T 或 2π 的尺度因子来自变换与内积的归一化，换坐标本身并没有改变信号的能量。

8.2 信号的表示与分解

直接记录每个位置的值，最容易回答“变化发生在哪里”；要判断一条记录由哪些振荡组成，则需要另一组坐标。表示的任务是描述同一对象，而不是先改变它。脉冲把各个位置的贡献分开，复指数把不同振荡的贡献分开，多项式则把位置编码为幂次，便于组织后面的卷积计算。每次转换都要说明哪些坐标足以恢复原信号，以及无穷展开按何种意义收敛。

8.2.1 时域表示与脉冲分解

把一个读数放回它原来的位置，可以用“仅在该位置为一”的信号来完成。对整数 r ，约定平移算子为

$$(T_r x)[k] = x[k - r].$$

$r > 0$ 时，原来位于 k 的值移动到 $k + r$ ，因而表示延迟。单位脉冲定义为

$$\delta[k] = \begin{cases} 1, & k = 0, \\ 0, & k \neq 0. \end{cases}$$

于是 $T_r \delta[k] = \delta[k - r]$ 只在位置 r 非零。任意有限支撑信号都有展开

$$x[k] = \sum_{r \in \mathbb{Z}} x[r] \delta[k - r]. \quad (8.4)$$

例如贯穿输入就是 $\delta[k] + 2\delta[k - 1] + \delta[k - 2]$ 。对每个固定 k ，只有 $r = k$ 的一项留下；对有限支撑输入，整个表达还是有限和。后文系统若允许叠加，就可分别计算这些脉冲的输出再相加。

有限记录上的各位置脉冲是标准正交基，系数恰好是原读数，完整展开不会丢失信息。若只保留位置集合 S ，得到 $x_S[k] = x[k] \mathbb{I}_S(k)$ ，则

$$\|x - x_S\|_2^2 = \sum_{k \notin S} |x[k]|^2.$$

这一步把完整的脉冲展开改成只保留部分位置的近似，误差正是被舍弃位置的幅值平方和。对 $x = (1, 2, 1)$ 只保留中间位置，近似为 $(0, 2, 0)$ ，平方误差为 2。保留一个时域系数与保留一个频域系数，舍弃的是不同方向，不能仅按系数个数比较误差。对 $x \in \ell_2$ ，对称截断 $\sum_{|r| \leq K} x[r] T_r \delta$ 在 ℓ_2 中

趋于 x ；这是尾部平方和趋零的结果，不是对任意信号都成立的无条件范数收敛。

8.2.2 频域表示与傅里叶分解

脉冲在平移后换了位置，复指数却保持形状。对 $\phi_\omega[k] = e^{i\omega k}$ 有

$$(T_r \phi_\omega)[k] = e^{i\omega(k-r)} = e^{-i\omega r} \phi_\omega[k].$$

平移只乘上模长为一的系数，因此这些振荡是平移算子的特征模式。频率 ω 区分振荡快慢；平移后乘上的复系数记录了振荡相位怎样随时间原点改变。这给出选择频率坐标的动机；具体用有限和、无穷级数还是积分，仍由时间索引及周期条件决定。以下离散公式以 n 记时间位置、 k 记频率格点。

8.2.2.1 有限离散信号的傅里叶表示

长度 N 的有限记录若采用循环索引，允许的复指数必须在移动 N 格后回到原值。因此频率取 $2\pi k/N$ 。令 $\omega_N = e^{-2\pi i/N}$ 。

定义 8.5 离散傅里叶变换 对 $N \geq 1$ 及 $x \in \mathbb{C}^N$ ，离散傅里叶变换 (discrete Fourier transform, DFT) 及逆变换为

$$\hat{x}[k] = \sum_{n=0}^{N-1} x[n] \omega_N^{kn}, \quad k = 0, \dots, N-1, \quad (8.5)$$

$$x[n] = \frac{1}{N} \sum_{k=0}^{N-1} \hat{x}[k] \omega_N^{-kn}, \quad n = 0, \dots, N-1. \quad (8.6)$$

循环索引是这组基的边界条件，不是对真实观测过程永久重复的断言。逆公式的依据是单位根正交关系：对整数 n, s ,

$$\sum_{k=0}^{N-1} \omega_N^{k(n-s)} = \begin{cases} N, & n \equiv s \pmod{N}, \\ 0, & n \not\equiv s \pmod{N}. \end{cases} \quad (8.7)$$

第一种情形每项都是 1。第二种情形令 $q = \omega_N^{n-s} \neq 1$ ，则 $q^N = 1$ ，几何级数给出 $(1 - q^N)/(1 - q) = 0$ 。将正变换代入逆变换，直接得到

$$\frac{1}{N} \sum_{k=0}^{N-1} \sum_{s=0}^{N-1} x[s] \omega_N^{k(s-n)} = \sum_{s=0}^{N-1} x[s] \mathbb{I}_{\{s=n\}} = x[n].$$

两次求和都是有限和，没有交换极限的问题；这证明全部 N 个系数能精确恢复记录。只保留其中一部分则是另一项截断操作。

记 DFT 矩阵为 $\mathbf{F}$, $F_{k+1,n+1} = \omega_N^{kn}$ 。矩阵的共轭转置 (conjugate transpose) 为 $\mathbf{F}^* = \overline{\mathbf{F}}^T$, 正交关系给出 $\mathbf{F}^* \mathbf{F} = N\mathbf{I}$, 所以 $\mathbf{F}/\sqrt{N}$ 才是酉矩阵。由此

$$\|\hat{\mathbf{x}}\|_2^2 = \mathbf{x}^* \mathbf{F}^* \mathbf{F} \mathbf{x} = N \|\mathbf{x}\|_2^2,$$

得到本章归一化下的 Parseval 关系

$$\sum_{n=0}^{N-1} |x[n]|^2 = \frac{1}{N} \sum_{k=0}^{N-1} |\hat{x}[k]|^2. \quad (8.8)$$

正逆变换若各用 $1/\sqrt{N}$, 等式便没有额外因子。多通道 DFT 逐通道变换时, 对各通道的等式求和就得到总能量关系, 不把通道数误当作变换长度。

每个非零系数可写成 $\hat{x}[k] = |\hat{x}[k]|e^{i \arg \hat{x}[k]}$ 。模长是该频率坐标的大小, 相角是相对于时间原点的相位。模长还不能直接当作实余弦的峰值, 还要考虑正负频率配对和 $1/N$ 归一化。循环平移 r 格后, 换元得到

$$\widehat{T_r x}[k] = \omega_N^{kr} \hat{x}[k].$$

因此幅度不变, 相位随 k 线性改变。若只保存幅度, 便不能区分这些位置不同的信号。零系数没有确定的相角, 软件为它返回的角度不携带波形信息。

实信号还具有共轭对称 (conjugate symmetry), 因为

$$\overline{\hat{x}[k]} = \sum_{n=0}^{N-1} x[n] \omega_N^{-kn} = \hat{x}[(N-k) \bmod N].$$

$k=0$ 的系数总是实数; N 为偶数时, $k=N/2$ 对应交替变号模式 $(-1)^n$, 其离散角频率 π 称为 Nyquist 频率, 该处系数也为实数。其余频率成对出现, 使用单边频谱时必须说明这两个端点是否加倍。

为看清幅度相同、相位不同的情形, 这里暂换成长度 8 的余弦记录。例如 $x[n] = \cos(2\pi n/8)$ 只在 $k=1, 7$ 有非零 DFT 系数, 二者都为 4; 延迟两格的 $z[n] = x[(n-2) \bmod 8]$ 在这两处变为 $-4i$ 与 $4i$ 。两条信号的能量都为 4, 也等于 $(4^2 + 4^2)/8$ 。图 8.1 在同一频率顺序下比较幅度和相位, 帮助分清具有相同的频谱幅度与具有相同波形的区别。

这里的复指数坐标来自规则循环平移: 每次移动都有统一的方向和步长, DFT 同时分解这些平移。如果位置只通过不规则的连接关联, 就不能再根据编号判断谁是“下一格”。第 9.5.1.1 节将用图上的连接定义变化, 并通过环图说明本节的复指数怎样成为图谱的一个特例。




图 8.1 长度 8 的教学信号 $x[n] = \cos(2\pi n/8)$ 及其循环延迟两格的结果。上方波形的峰值位置不同，下方在 $k = 1, 7$ 的幅度均为 4，相位却改变。相位图只画非零系数；波形连线只帮助观察顺序，不表示已选择连续时间插值。

8.2.2.2 周期连续信号的傅里叶表示

连续时间的一个周期含无穷多个位置，有限个坐标一般不足以完整描述。周期条件仍把频率限制在整数谐波上，但展开变为无穷级数。

定义 8.6 周期信号的傅里叶系数与级数 设 $T > 0$, $f \in L^2[0, T]$ 并按周期 T 延拓。在内积

$$\langle f, g \rangle_T = \frac{1}{T} \int_0^T f(t) \overline{g(t)} dt$$

下，复指数 $e^{i2\pi kt/T}$ 组成正交归一基。傅里叶系数 (Fourier coefficient) 为

$$c_k = \frac{1}{T} \int_0^T f(t) e^{-i2\pi kt/T} dt, \quad k \in \mathbb{Z},$$

相应傅里叶级数写作

$$f(t) \sim \sum_{k \in \mathbb{Z}} c_k e^{i2\pi kt/T}. \quad (8.9)$$

正交性由对 $e^{i2\pi(k-j)t/T}$ 积分得到: $k = j$ 时归一化积分为 1, 否则两个端点的指数相同, 积分为 0。完备性给出对称部分和 $S_K f = \sum_{|k| \leq K} c_k e^{i2\pi kt/T}$ 的 L^2 收敛, 即 $T^{-1} \int_0^T |S_K f - f|^2 \rightarrow 0$ 。它描述一个周期的平均平方误差, 不能单凭这一结论就在每个 t 写逐点等号。

由正交展开及其极限得到

$$\frac{1}{T} \int_0^T |f(t)|^2 dt = \sum_{k \in \mathbb{Z}} |c_k|^2. \quad (8.10)$$

左侧是周期平均功率；单周期能量还要乘以 T ，整轴能量通常无穷。相应截断误差为 $\sum_{|k| > K} |c_k|^2$ 。实信号满足 $c_{-k} = \overline{c_k}$ ，延迟 τ 则把 c_k 变为 $e^{-i2\pi k\tau/T} c_k$ ，幅相的作用与有限情形相同。

逐点重构需增加规则性。例如在一个周期内分段 C^1 、只有有限个跳跃点且单侧极限存在时，傅里叶级数在连续点趋于 $f(t)$ ，在跳跃点趋于左右极限平均。这是带条件的结论；不能把均方收敛与逐点或一致收敛互换，三种收敛方式的区别及各自需要的条件可回查第 3 章。

取周期 2π 的方波： $0 < t < \pi$ 时为 1， $-\pi < t < 0$ 时为 -1。平均值 $c_0 = 0$ ；对 $k \neq 0$ 直接积分，

$$c_k = \frac{1}{2\pi} \left(\int_0^\pi e^{-ikt} dt - \int_{-\pi}^0 e^{-ikt} dt \right) = \frac{1 - (-1)^k}{\pi i k}.$$

因此偶数 k 的系数为零，奇数 k 的系数为 $2/(\pi i k)$ ，也可配对写成

$$\frac{4}{\pi} \left(\sin t + \frac{\sin 3t}{3} + \frac{\sin 5t}{5} + \cdots \right).$$

连续点处恢复 ± 1 ，跳跃点处趋于 0，无论给原函数的跳跃点赋什么值，其 L^2 元素和傅里叶系数都不变。Parseval 仍给出 $1 = (8/\pi^2) \sum_{j=0}^{\infty} (2j+1)^{-2}$ 。平均平方误差趋零并不排除跳跃附近的局部振荡；这也是有限谐波近似尖锐边沿时需要单独观察局部误差的原因。

8.2.2.3 整轴离散信号的傅里叶表示

一条整轴序列不必周期，频率也不再局限于 N 个格点。但整数 n 使 $e^{-i(\omega+2\pi)n} = e^{-i\omega n}$ ，因此频率变量虽然连续，频率表示仍以 2π 为周期。

定义 8.7 离散时间傅里叶变换 对 $x \in \ell_1(\mathbb{Z})$ ，离散时间傅里叶变换 (discrete-time Fourier transform, DTFT) 定义为

$$X(e^{i\omega}) = \sum_{n \in \mathbb{Z}} x[n] e^{-i\omega n}, \quad \omega \in \mathbb{R}. \quad (8.11)$$

绝对可和使级数绝对且一致收敛，因而定义连续的 2π 周期函数。

记号 $X(e^{i\omega})$ 强调只沿单位圆取值，不在这里假设存在一般复变量的解析延拓。对 $x \in \ell_2$ ，相同级数改按 $L^2([-\pi, \pi])$ 收敛解释，所得对象是等价

类, 不要求每个 ω 都能按普通级数求值。两种情形均有系数恢复与能量关系

$$x[n] = \frac{1}{2\pi} \int_{-\pi}^{\pi} X(e^{i\omega}) e^{i\omega n} d\omega,$$

$$\sum_n |x[n]|^2 = \frac{1}{2\pi} \int_{-\pi}^{\pi} |X(e^{i\omega})|^2 d\omega.$$

在 ℓ_1 情形可把绝对收敛级数移入积分, 单位复指数的正交性留下第 n 项; ℓ_2 情形则来自周期 L^2 空间的正交基与 Parseval 关系。

贯穿例零延拓后的 DTFT 为 $X(e^{i\omega}) = 1 + 2e^{-i\omega} + e^{-2i\omega}$, 它是连续频率曲线。对 $N \geq 3$, 将记录补零到 N 项后计算 DFT, 只是读取这条曲线在 $\omega = 2\pi k/N$ 上的值。补更多零增加了频率格点密度, 没有增加原记录的信息或延长真实观测。相反, 若原序列无穷长, 先截取 N 项再作 DFT, 频谱已受时间截断影响, 不能把结果直接称为完整 DTFT 的精确采样。离散频率 ω 的单位是弧度每样本; 样本间隔为 T_s 时才换算成连续角频率 $\Omega = \omega/T_s$, 并保留模 $2\pi/T_s$ 的歧义。

8.2.2.4 整轴连续信号的傅里叶表示

整条时间实轴既没有有限长度, 也不预设周期, 复指数坐标随连续频率变化。求和相应变成积分。若积分绝对收敛, 可以直接按积分计算; 若信号只满足平方可积, 则需要通过范数极限来定义变换。

定义 8.8 连续时间傅里叶变换 对 $f \in L^1(\mathbb{R})$, 连续时间傅里叶变换为

$$F(\Omega) = \int_{\mathbb{R}} f(t) e^{-i\Omega t} dt.$$

若还满足 $F \in L^1$, 逆变换

$$f(t) = \frac{1}{2\pi} \int_{\mathbb{R}} F(\Omega) e^{i\Omega t} d\Omega$$

在几乎处处意义下成立, 右侧给出连续代表元; 在原 f 的连续点也恢复其点值。在 $L^1 \cap L^2$ 上使用同一积分公式, Plancherel 定理将变换唯一延拓到 L^2 , 满足

$$\int_{\mathbb{R}} |f(t)|^2 dt = \frac{1}{2\pi} \int_{\mathbb{R}} |F(\Omega)|^2 d\Omega.$$

一般 L^2 情形的正逆变换按范数极限理解, 不保证普通积分在每个频率或时刻存在。例如改变单个点值不会改变 L^2 元素, 变换不可能判断这个点后来被赋成哪个值。第 8.4.2.1 节将借助带限条件选定连续代表元, 然后才读取采样点; 不能对任意等价类未经说明直接采样。

一个可直接积分的例子是 $f = \mathbb{I}_{[0,1]}$:

$$F(\Omega) = \begin{cases} (1 - e^{-i\Omega})/(i\Omega), & \Omega \neq 0, \\ 1, & \Omega = 0. \end{cases}$$

它在时间上只持续一个单位区间, 频谱却没有有限支撑。有限持续时间并不等于带限。对满足积分条件的实信号, $F(-\Omega) = \overline{F(\Omega)}$; 延迟 τ 使频谱乘上 $e^{-i\Omega\tau}$, 仍只改相位不改幅度。这里 Ω 以弧度每单位时间计, 不能与 DFT 的无量纲索引 k 直接比较。

表 8.1 汇总四种对象。它们的共同点是复指数坐标, 差别来自索引与周期条件, 而不是四个名称可以互换。

表示	输入对象及边界	频率坐标	成立条件与收敛意义
DFT	N 项数组, 基采用循环索引	N 个频率格点	有限和, 可逆
傅里叶级数	一个周期上的函数	全部整数谐波	L^2 均方展开; 逐点另需条件
DTFT	整数轴序列, 不要求周期	连续且 2π 周期	ℓ_1 下连续; ℓ_2 下为 L^2 等价类
连续傅里叶变换	实轴函数, 不要求周期	连续实频率	L^1 积分或 L^2 延拓

表 8.1 信号对象决定傅里叶表示的频率轴及收敛意义。离散时间不表示频率必然离散, 频谱周期也不表示原序列周期; 有限 DFT 与整轴 DTFT 还相差记录范围及边界约定。

8.2.3 有限信号的代数表示

有限序列还有一种不依赖物理频率的表示: 把位置写成多项式的幂次。完整系数、足够多的点值和足够多的互素余数可以描述同一个有限对象。先确定这些表示的可逆条件, 后文才利用它们计算乘积, 避免把少算几次乘法误解为恢复同一对象所需的信息也变少了。

8.2.3.1 位置系数下的多项式表示

对 $\mathbf{x} = (x_0, \dots, x_{m-1})$ 定义

$$X(z) = \sum_{j=0}^{m-1} x_j z^j.$$

其中 $x_j = x[j]$, 形式变量 z 首先只记录位置, 并不是给系统施加的输入。长度固定后, 序列与次数小于 m 的多项式一一对应; 最高位置可以是零, 所以次数未必恰好为 $m-1$ 。例如贯穿示例中的两条记录分别对应 $X(z) = 1 + 2z + z^2$ 和 $H(z) = 1 - z$ 。移动一个位置并保留前导零对应乘以 z , 而是否把高次项回绕到低次项, 仍要由边界另行规定。正变换 DFT 正

是 X 在单位根 ω_N^k 处的求值；多项式在这里连接位置系数与另一组坐标，并未改变记录本身。

8.2.3.2 互异点值下的插值表示

已知一个多项式在若干位置的值，何时足以恢复全部系数？答案同时依赖次数界与选点。次数小于 L 的多项式构成 L 维空间。选取 L 个两两不同的点 $a_0, \dots, a_{L-1}$ ，求值映射

$$E(P) = (P(a_0), \dots, P(a_{L-1}))$$

是线性的。若 $E(P) = 0$ ，则 P 有 L 个不同根；次数小于 L 的非零多项式至多有 $L-1$ 个根，因此 $P = 0$ 。同维空间间的单射必为双射，逆映射就是多项式插值（polynomial interpolation）。

显式恢复可用 Lagrange 基

$$\ell_j(z) = \prod_{\substack{0 \leq k < L \\ k \neq j}} \frac{z - a_k}{a_j - a_k}.$$

互异性保证分母非零，且 $\ell_j(a_k) = \delta_{j,k}$ 。故 P 与下式右侧在 L 个点相同、次数都小于 L ，由刚才的唯一性得到

$$P(z) = \sum_{j=0}^{L-1} P(a_j) \ell_j(z), \quad \deg P < L. \quad (8.12)$$

例如一次多项式在 0, 1 的值为 1, 3，便恢复为 $1(1-z) + 3z = 1 + 2z$ 。若允许二次项，则 $1 + 2z + c z(z-1)$ 对任意 c 都给出相同两点值，说明次数界不可省。重复读取同一点也不增加独立约束；导数观测属于另一种插值问题。

代数上的唯一恢复解决了“是否有另一个多项式给出同样点值”的问题，却没有解决“点值稍有误差时，系数会改变多少”的问题。点值到系数的矩阵逆可能放大测量或舍入误差，相近选点以及较高次数尤其需要检查条件数；其含义与计算见第 6 章。单位根的归一化 DFT 是条件良好的特殊选点，一般实点并没有同样保证。

8.2.3.3 互素余数下的模分解表示

点值只保留一个数；有时保留关于低次多项式的余数更方便。余数记录除掉某个模多项式后还剩下的部分，既比完整系数小，又能与其他余数合起来恢复。为使这种说法有确定含义，先建立除法与唯一性，以下以 F 表示系数域。域（field）是一套遵守通常加乘运算律、可以加减乘除且非零元

素都能作除数的数系；本节可以先取熟悉的 $\mathbb{R}$ 或 $\mathbb{C}$ 。 $F[z]$ 表示系数在 F 中的有限多项式全体，采用通常的多项式加法与乘法。

定理 8.9 多项式带余除法 设 $A, M \in F[z]$ 且 $M \neq 0$ ，存在唯一的 $Q, R \in F[z]$ 满足

$$A = QM + R, \quad \deg R < \deg M.$$

约定零多项式的次数为 $-\infty$ 。

证明. 若 $\deg A < \deg M$ ，取 $Q = 0, R = A$ 。否则设最高次项分别为 $a_p z^p$ 与 $m_q z^q$ ， $p \geq q$ 。域中 m_q 可逆，减去 $(a_p/m_q)z^{p-q}M$ 就消掉最高次项。每步次数严格下降，有限步后便得到次数小于 $\deg M$ 的余数。

若还有 $A = Q'M + R'$ ，则 $(Q - Q')M = R' - R$ 。左侧若非零，次数至少为 $\deg M$ ；右侧若非零，次数小于 $\deg M$ ，矛盾。因此两侧都为零， $Q = Q'$ 、 $R = R'$ 。 ■

为了判断几份余数是否提供相互独立的约束，需要检查模多项式是否互素。这可以先通过最大公因式来判断。对非零 A, B 反复带余除法，

$$A = Q_0 B + R_1, \quad B = Q_1 R_1 + R_2, \quad \dots$$

非零余数的次数严格下降，过程必有限终止。由 $A = Q_0 B + R_1$ 可见， A, B 的公因式恰好是 B, R_1 的公因式；逐步应用，最后一个非零余数首项归一化后就是最大公因式 (greatest common divisor)。从最后一个等式向前回代，每个余数均为 A, B 的多项式线性组合，得到

$$U(z)A(z) + V(z)B(z) = \gcd(A, B). \quad (8.13)$$

这是 Bézout 恒等式。互素表示最大公因式为非常数，等价于存在 U, V 使左侧为 1。例如在 $\mathbb{R}[z]$ 中，

$$z^2 + 1 = (z + 1)(z - 1) + 2, \quad 1 = \frac{1}{2}(z^2 + 1) - \frac{1}{2}(z + 1)(z - 1).$$

它既证明 $z - 1$ 与 $z^2 + 1$ 互素，也提供了后面重构所需的逆元。

把余数记为 $A \bmod M$ ，把相差 M 倍数的多项式看成同一个剩余类 (residue class)，记为 $[A]_M$ 。当 $M = z - a$ 时，除法式在 $z = a$ 处给出 $A(z) = Q(z)(z - a) + A(a)$ ，所以点值恰好是关于一次模的常数余数。多个余数如何恢复同一对象，由下述定理回答。

定理 8.10 多项式中国剩余定理 设非恒定多项式 $m_1, \dots, m_s \in F[z]$ 两两互素, 令 $M = \prod_{j=1}^s m_j$ 。映射

$$[A]_M \mapsto ([A]_{m_1}, \dots, [A]_{m_s})$$

是环同构 (ring isomorphism), 即双射并且保持加法和乘法; 余数类相加或相乘, 都是先作多项式运算再对相应的模取余。因此全部余数唯一确定次数小于 $\deg M$ 的代表元 $A \bmod M$ 。

证明. 若 $A - B$ 是 M 的倍数, 它也是各 m_j 的倍数, 故映射不依赖代表元; 取余还保持加法与乘法。若 A, B 的各个余数都相同, 则每个 m_j 整除 $A - B$ 。为证明乘积也整除, 先设互素的 a, b 均整除 q , 写 $q = ac$ 。由 $ua + vb = 1$ 有 $c = uac + vbc = uq + vbc$, 所以 b 整除 c , 从而 ab 整除 q 。两两互素时, 若某多项式分别与 a, b 互素, 将对应 Bézout 等式相乘即可证明它与 ab 互素。反复使用前述整除结论, 便有 $M \mid (A - B)$, 映射为单射。

给定任意余数 r_j , 令 $M_j = M/m_j$ 。互素性与 Bézout 恒等式给出 $u_j M_j + v_j m_j = 1$ 。因此 $e_j = u_j M_j$ 关于 m_j 的余数是 1, 关于其他 m_k 的余数是 0。取

$$A = \sum_{j=1}^s r_j e_j$$

即具有全部指定余数, 故映射满射。最后对 M 取余, 带余除法给出唯一的次数小于 $\deg M$ 代表元。 ■

各个模两两互素, 保证任意指定的余数都能拼成一个剩余类。若原多项式次数还小于总模的次数, 这个剩余类就能唯一确定原多项式。两项条件承担不同作用。例如知道 $P \bmod z$ 和 $P \bmod (z - 1)$ 可以恢复一次多项式, 却无法区分 P 与 $P + cz(z - 1)$; 反复使用同一个模更不增加信息。在模 $z^N - 1$ 下, z^{N+s} 与 z^s 属于同一剩余类, 因而高次系数按模 N 合并。这个规则将编码循环边界, 但此时还没有计算两个信号的乘积。余数恢复如何减少卷积计算, 留到第 8.3.4 节。

8.3 信号的运算与映射

表示回答同一条信号怎样描述, 运算则回答它怎样变成另一条信号。移动、反转、缩放及叠加是基本操作; 输入输出映射把这些操作组合为滤波或历史响应, 相关则比较模板与局部片段。这些映射可能允许叠加, 也可能在输入平移后给出同样平移的输出, 还可能只使用过去与当前的输入。这三个要求彼此不同, 需要分别判断。快速算法也必须在目标映射明确后讨论。

8.3.1 信号的基本运算

为避免对称波形掩盖方向差异，本节固定一个非对称三角脉冲：

$$x(t) = \begin{cases} 2t, & 0 \leq t \leq 1, \\ 3-t, & 1 < t \leq 3, \\ 0, & \text{其余位置.} \end{cases} \quad (8.14)$$

它在 $t = 1$ 达到峰值 2，上升历时 1、下降历时 2，能量为 $\int_0^1 4t^2 dt + \int_1^3 (3-t)^2 dt = 4$ 。图 8.2 始终用它作参照。

8.3.1.1 平移下的位置变化

连续时间的延迟 τ 写成 $(T_\tau x)(t) = x(t - \tau)$ ；离散时间沿用 $(T_r x)[k] = x[k - r]$ ，只允许整数 r 。正参数使已有特征推迟出现，负参数使其提前。例如 $x(t - 1)$ 的峰值从 $t = 1$ 移到 $t = 2$ ，支撑从 $[0, 3]$ 移到 $[1, 4]$ 。长度 N 的循环延迟则为 $x[(k - r) \bmod N]$ ，越过右端的值回到左端。对有限非循环记录，必须先按第 8.1 节约定延拓，再决定是否裁剪到原窗口，不能将丢出窗口的值自动送回首端。

对整轴上同一信号空间的 x, z ，换元给出 $\langle T_\tau x, T_\tau z \rangle = \langle x, z \rangle$ ；离散情形用求和换标，循环情形用有限位置的置换得到相同结论。相应的整轴 L^p 、 ℓ_p 范数和能量均不变。但固定窗口 $[0, 3]$ 内， $x(t - 1)$ 只保留原波形的 $[0, 2]$ 部分，窗口能量从 4 降为 11/3。这是裁剪改变了观测范围，不是平移在整轴上消耗了能量。

8.3.1.2 反转下的方向变化

时间反转定义为 $(Rx)(t) = x(-t)$ ，离散整轴上为 $(Rx)[k] = x[-k]$ 。它把发生次序沿原点翻转，式 (8.14) 的支撑变为 $[-3, 0]$ ，峰值位于 -1 。有限数组通常说的“反序”却是 $x_{\text{rev}}[k] = x[N - 1 - k]$ ， $0 \leq k < N$ ；按整轴零延拓，它等于 $T_{N-1}Rx$ ，是在反转后平移回记录窗口。循环反转则用 $x[(-k) \bmod N]$ ，位置 0 保持不动，与数组反序也不同。

反转不改变幅值符号；取负 $-x(t)$ 才把正值变成负值，复共轭 $\overline{x(t)}$ 只改变每个位置的虚部符号。例如非对称非负波形反转后仍非负，取负后却非正；复信号 $(1 + i)\mathbb{1}_{[0,1]}(t)$ 的共轭仍支持在 $[0, 1]$ ，而时间反转支持在 $[-1, 0]$ ，两者不能互换。换元 $t \mapsto -t$ 或 $k \mapsto -k$ 表明整轴反转保持内积、范数与能量。后文卷积中的核反转、相关改写中额外的复共轭，将分别使用这里的两项操作。

8.3.1.3 幅值缩放与信号叠加

标量倍乘 $(ax)(t) = a x(t)$ 改变幅值, 逐点相加 $(x+z)(t) = x(t) + z(t)$ 组合同时位置的值。对任意范数, $\|ax\| = |a|\|x\|$, 故能量为 $E_{ax} = |a|^2 E_x$; 若长期平均功率存在, 也乘以 $|a|^2$ 。图中的 $2x(t)$ 保持峰值时刻和支撑不变, 峰值变为 4, 能量变为 16, 与把时间压缩一半不是一件事。

叠加时的能量含有干涉项。沿用第一变量线性的内积,

$$\|ax + bz\|_2^2 = |a|^2 \|x\|_2^2 + |b|^2 \|z\|_2^2 + 2 \operatorname{Re}(a\bar{b} \langle x, z \rangle).$$

正交信号的能量直接相加; 一般信号可能相互增强或抵消。有限记录 $x = (1, 2, 1)$ 与 $z = (1, 0, -1)$ 正交, 故 $\|x + z\|_2^2 = 6 + 2 = 8$; 取 $z = x$ 则 $\|x + z\|_2^2 = 24$ 而不是 12, 取 $z = -x$ 更会完全抵消。

多通道统一缩放是 $ax[k]$, 逐通道缩放是对角矩阵 $Dx[k]$, 一般矩阵 $Bx[k]$ 还混合不同通道。后两种操作不必按同一比例改变总能量; 只有 $B^*B = I$ 时才对所有输入保持欧氏通道能量。这同时说明“组合两路传感器”必须给出矩阵及通道单位, 不能默认为没有损失的重命名。

8.3.1.4 时间缩放与尺度变化

对连续时间和 $a \neq 0$, 定义 $y(t) = x(at)$ 。 $|a| > 1$ 把时间压缩, $0 < |a| < 1$ 把时间伸展, $a < 0$ 还附带时间反转。若 x 的某个特征位于 t_0 , y 中的同一特征就位于 t_0/a 。图中的 $x(2t)$ 峰值仍为 2, 但峰值时刻变为 $1/2$, 支撑缩短为 $[0, 3/2]$ 。对有限能量信号, 换元 $s = at$ 给出

$$E_y = \int_{\mathbb{R}} |x(at)|^2 dt = \frac{1}{|a|} \int_{\mathbb{R}} |x(s)|^2 ds = \frac{E_x}{|a|}.$$

因此 $x(2t)$ 的能量为 2; 幅值未变, 累计时间却减少。若需要缩放时间同时保持二范数, 应使用 $|a|^{1/2}x(at)$ 。当平均功率存在时, 同样换元并把平均窗口一起缩放, 得到 $P_y = P_x$, 这与总能量的尺度因子并不矛盾。

整数索引不能随意替换成实数。 $x[Mk]$ 对正整数 M 有定义, 表示每 M 项抽取一项; $x[k/M]$ 在 k 不是 M 倍数时没有已有样本可读。插零上采样先规定 $u[k] = x[k/M]$ 在 $M \mid k$ 时成立、其余位置为零, 再由插值规则生成中间值。插零本身不是已经恢复连续波形, 抽取也没有连续时间换元那样的通用能量比例。采样后保留什么信息, 须在第 8.4 节另行判断。

8.3.2 信号的输入输出映射

假设要从传感器记录中突出突然变化: 我们可以在每个时刻计算当前读数与前一个读数的差。这里已经确定了输入记录, 以及由它生成输出的规则。更一般地, 把输入信号映为输出信号的规则称为系统, 写成 $y = \mathcal{H}x$ 。在有




图 8.2 对同一非对称三角脉冲分别延迟、反转、放大幅值和压缩时间。每幅图的蓝线均为式 (8.14) 的原信号, 红线为指定操作结果, 横轴为时间、纵轴为幅值, 坐标尺度一致。平移和反转保持整轴能量 4, 幅值乘 2 使能量变为 16, 时间压缩为一半使能量变为 2; 各图均在整轴零值背景下观察, 不作窗口裁剪。

限位置上, 线性规则可写成 $y[n] = \sum_r K[n, r]x[r]$, 其中 $K[n, r]$ 说明位置 r 的单位输入怎样影响位置 n 的输出。整轴表达还需收敛条件, 不能仅凭这个形式就交换无穷求和。若输入、输出有 d_{in} 和 d_{out} 个通道, 则 $K[n, r]$ 应为 $d_{\text{out}} \times d_{\text{in}}$ 矩阵, 矩阵乘法负责混合通道, 求和负责汇总时间位置, 两者职责不同。

这里的因果性只表示“不读取未来输入”: 若两条输入在所有 $r \leq n$ 的位置相同, 则它们在时刻 n 的输出必须相同。对可用脉冲逐项检验的线性核映射, 这等价于 $K[n, r] = 0$ 在 $r > n$ 时成立。它不是第12章用于预定义的因果响应; 只按过去顺序计算一个预测量, 不会自动证明其统计关系具有干预含义。

8.3.2.1 线性时不变条件下的卷积映射

如果改变输入幅值可以按比例叠加, 而且同一个局部输入移到哪里都触发同形响应, 就有希望只保存一条响应核。两项要求需要分别定义。

定义 8.11 线性时不变系统 设输入、输出信号类为平移封闭的向量空间。若对任意标量 a, b 及输入 x, z 有 $\mathcal{H}(ax + bz) = a\mathcal{H}x + b\mathcal{H}z$, 称 $\mathcal{H}$ 线性。若对每个整数 r 有

$$\mathcal{H}(T_r x) = T_r(\mathcal{H}x),$$

称其具有平移不变性 (shift invariance)。同时满足两者的系统称为线性时不变系统 (linear time-invariant system, LTI)。

这里输入整体移动后输出同样移动, 并不是输出保持在原位置。逐点平方 $\mathcal{H}x[n] = x[n]^2$ 平移不变却不线性, 位置加权 $\mathcal{H}x[n] = nx[n]$ 线性却不平移不变。是否在每个位置调用了同一段程序, 不足以替代这两项等式。

要利用这两项条件避免逐个输入重做分析, 可以先考察最简单的输入: 只在位置 0 给出一个单位脉冲。令 $h = \mathcal{H}\delta$, 称为脉冲响应 (impulse response)。平移不变性决定其他位置的脉冲响应, 线性性再把它们叠加起来。有限支撑输入可按式 (8.4) 作有限展开, 线性性与平移不变性给出

$$\begin{aligned} (\mathcal{H}x)[n] &= \mathcal{H}\left(\sum_r x[r]T_r\delta\right)[n] \\ &= \sum_r x[r](T_r h)[n] = \sum_r x[r]h[n-r]. \end{aligned} \quad (8.15)$$

它把各位置输入所触发的响应相加。对 $x \in \ell_1(\mathbb{Z})$, 还需 $\mathcal{H} : \ell_1 \rightarrow \ell_1$ 为有界线性且平移不变的算子, 即存在常数 C 使 $\|\mathcal{H}x\|_1 \leq C\|x\|_1$ 。令

$x^{(K)} = \sum_{|r| \leq K} x[r]T_r\delta$, 则 $x^{(K)} \rightarrow x$ 于 ℓ_1 , 有界性使 $\mathcal{H}x^{(K)} \rightarrow \mathcal{H}x$ 。同时 $h = \mathcal{H}\delta \in \ell_1$, 且

$$\sum_n \sum_r |x[r]h[n-r]| = \|x\|_1 \|h\|_1 < \infty.$$

因此卷积和绝对收敛, 有限截断的卷积也在 ℓ_1 中趋于该和, 从而式(8.15)延伸到全部 ℓ_1 输入。不能省略连续性, 直接把仅对有限和成立的代数线性搬进无穷和。

这种求和称为离散卷积 (discrete convolution), 规则网格上也可用同一结构。

定义 8.12 网格上的离散卷积 对 $x, h \in \ell_1(\mathbb{Z}^d)$, 定义

$$(x * h)[n] = \sum_{r \in \mathbb{Z}^d} x[r]h[n-r]. \quad (8.16)$$

这里 n, r 为网格位置, h 称为卷积核 (convolution kernel)。各位置的和绝对收敛, 输出仍属于 $\ell_1(\mathbb{Z}^d)$ 。

存在性可直接检查: 对非负项换序并令 $s = n - r$, 有

$$\sum_n \sum_r |x[r]h[n-r]| = \left(\sum_r |x[r]| \right) \left(\sum_s |h[s]| \right) < \infty.$$

所以每个内层和均有限, 并得到 $\|x * h\|_1 \leq \|x\|_1 \|h\|_1$ 。核为有限支撑时, 对任何逐点有限的输入也可作有限和, 但输出不因此必属 ℓ_1 。一维记法为

$$(x * h)[n] = \sum_{r \in \mathbb{Z}} x[r]h[n-r]. \quad (8.17)$$

固定 n 后, r 增加时核索引 $n-r$ 减小, 这就是核的反向读取。令 $s = n - r$ 可得 $(x * h)[n] = \sum_s h[s]x[n-s] = (h * x)[n]$, 故有交换律; 绝对可和等允许换序的条件还给出结合律和分配律。若 $h[r] = 0$ 对所有 $r < 0$ 成立, 则 $y[n] = \sum_r h[r]x[n-r]$ 只用当前及过去输入, 系统因果; 一般 LTI 则不必因果, 例如三点中心均值会使用 $x[n+1]$ 。

连续输入的局部贡献改用积分累计。

定义 8.13 连续卷积 设 $f, g \in L^1(\mathbb{R}^d)$, 定义

$$(f * g)(t) = \int_{\mathbb{R}^d} f(\tau)g(t-\tau) d\tau. \quad (8.18)$$

积分对几乎处处的 t 绝对收敛, 并定义 $L^1(\mathbb{R}^d)$ 中的元素。

由定理 3.41, 对非负函数换序并平移换元,

$$\int_{\mathbb{R}^d} \int_{\mathbb{R}^d} |f(\tau)g(t-\tau)| d\tau dt = \|f\|_{L^1} \|g\|_{L^1} < \infty.$$

内层积分因而几乎处处有限, 且 $\|f * g\|_{L^1} \leq \|f\|_{L^1} \|g\|_{L^1}$ 。换元和换序同样给出交换律、结合律, 但 L^1 假设不保证每个指定点的积分都有限。这里定义的是两个普通可积函数的卷积, 并非所有连续 LTI 算子都具有普通 L^1 核。例如恒等映射是 LTI, 它的单位脉冲响应可用 Dirac 分布 (Dirac distribution) δ_0 描述。这里“分布”采用广义函数的用语: 这个对象作用于光滑紧支撑的测试函数 ϕ 时返回 $\delta_0(\phi) = \phi(0)$, 也就是零点单位质量对 ϕ 的积分。对光滑紧支撑的 f , 与 δ_0 卷积就是让 δ_0 读取 $\tau \mapsto f(t-\tau)$ 在零点的值, 于是 $(f * \delta_0)(t) = f(t)$, 正好实现恒等映射。普通函数 $\mathbb{I}_{\{0\}}$ 的 Lebesgue 积分却为零, 不能承担这种单位质量, 所以不能把离散 $\delta[k]$ 直接当作连续可积核。当前不调用一般分布理论来证明所有连续系统的核表示。

示例 8.14 区间重叠产生三角形响应 取 $f(t) = g(t) = \mathbb{I}_{[0,1]}(t)$ 。两因子同时为 1 要求 $\tau \in [0, 1] \cap [t-1, t]$, 因此

$$(f * g)(t) = \begin{cases} t, & 0 \leq t \leq 1, \\ 2-t, & 1 < t \leq 2, \\ 0, & \text{其余位置.} \end{cases}$$

输出先随重叠长度增大而上升, 再随重叠减小而下降。二维指示函数的相应积分计算重叠面积, 一般带符号核则计算加权贡献, 不能都解释为几何大小。

图 8.3 区分输出位置 t 和积分变量 τ 。三角形输出不是把两个输入图形相加, 而是把每个 t 处的重叠长度汇成曲线。

回到有限输入。若 x, h 的支撑分别为 $0, \dots, m-1$ 和 $0, \dots, r-1$, 零延拓线性卷积只可能在 $0, \dots, m+r-2$ 非零, 完整输出长度为 $m+r-1$ 。贯穿例逐项为

$$\begin{aligned} (x * h)[0] &= 1, \\ (x * h)[1] &= 2 - 1 = 1, \\ (x * h)[2] &= 1 - 2 = -1, \\ (x * h)[3] &= -1. \end{aligned}$$

即

$$\mathbf{x} * \mathbf{h} = (1, 1, -1, -1). \quad (8.19)$$




图 8.3 教学函数 $f = g = \mathbb{I}_{[0,1]}$ 的连续卷积。左两图分别固定 $t = 0.5$ 与 $t = 1.5$ ，蓝色为 $f(\tau)$ 的支撑，红色为 $g(t - \tau)$ 的支撑，黄色重叠长度均为 0.5。右图汇总全部 t 处的重叠长度，在 $t = 1$ 时达到 1。左图横轴 τ 用于积分，右图横轴 t 标记输出位置。

这个核计算当前值减去前一个值，首尾还包含零延拓带来的跳变。长度 N 的循环索引则在一个周期内求和：

$$(x *_N h)[n] = \sum_{r=0}^{N-1} x[r]h[(n-r) \bmod N], \quad n = 0, \dots, N-1. \quad (8.20)$$

定义 8.15 循环卷积 对长度 N 的实或复序列，式 (8.20) 定义其循环卷积 (circular convolution)，输出仍有 N 项。它在有限循环索引集上求和，不是两条周期延拓序列在整数轴上的无穷卷积。

把 h 补成 $(1, -1, 0)$ 并取 $N = 3$ ，得到 $x *_3 h = (0, 1, -1)$ 。完整线性卷积的末项 -1 回绕到首项，与 1 相消；不是直接删掉了末项。若对两条周期序列在整轴无穷求和，同一贡献会被重复无穷次。图 8.4 对比零延拓与循环边界下的输出。

固定输入输出位置后，线性卷积是 Toeplitz 矩阵乘法，循环卷积是循环矩阵乘法。例如同一个贯穿例给出

$$\begin{bmatrix} 1 & 0 & 0 \\ -1 & 1 & 0 \\ 0 & -1 & 1 \\ 0 & 0 & -1 \end{bmatrix} \begin{bmatrix} 1 \\ 2 \\ 1 \end{bmatrix} = \begin{bmatrix} 1 \\ 1 \\ -1 \\ -1 \end{bmatrix},$$

$$\begin{bmatrix} 1 & 0 & -1 \\ -1 & 1 & 0 \\ 0 & -1 & 1 \end{bmatrix} \begin{bmatrix} 1 \\ 2 \\ 1 \end{bmatrix} = \begin{bmatrix} 0 \\ 1 \\ -1 \end{bmatrix}.$$




图 8.4 输入 $(1, 2, 1)$ 与核 $(1, -1)$ 的边界比较。蓝色圆点采用零延拓，给出四项线性卷积；红色方点采用长度 3 的循环边界，末项 -1 回到首项并与 1 抵消。连线只指示离散数值的顺序，不定义整数之间的信号值。

同一条对角线上的系数相同，说明不同位置使用同一组核参数；矩阵的首尾行则由边界规则决定。无限网格或循环群上的平移不变性是精确的；有限区间采用零填充、反射或截取后，通常不再具有同一意义的全局平移不变性。

“valid”只选择核完全落在已知输入内的输出。按 $h[0], \dots, h[r-1]$ 的因果索引，当 $m \geq r$ 时保留 $n = r-1, \dots, m-1$ ，共 $m-r+1$ 项； $m < r$ 时没有这样的输出。保持输入长度的“same”还需指定左右填充及截取位置，不能只凭名称确定。表 8.2 将延拓和输出选择分开，后文 FFT 也必须遵守同一约定。

约定	区间外输入	保留输出	贯穿例
完整线性卷积	零延拓	$0, \dots, m+r-2$	$(1, 1, -1, -1)$
有效区间选段	不使用区间外值	$r-1, \dots, m-1, \quad m \geq r$	$(1, -1)$
N 点循环卷积	周期边界	$0, \dots, N-1$	$N=3$ 时 $(0, 1, -1)$

表 8.2 边界延拓与输出选段。 m 为输入长度， r 为核长度，使用本章因果核索引。有效选段不是另一种卷积定义，循环边界也不是零边界的近似。

有了有限 DFT，循环卷积可在频率坐标中逐项计算。

定理 8.16 离散循环卷积定理 设 x, h 为长度 N 的复序列, 采用式 (8.5) 的约定, 则

$$\widehat{x * h}[k] = \hat{x}[k] \hat{h}[k], \quad k = 0, \dots, N-1.$$

证明. 令 $a = (n - r) \bmod N$, 直接换有限求和的索引,

$$\begin{aligned} \widehat{x * h}[k] &= \sum_{n=0}^{N-1} \sum_{r=0}^{N-1} x[r] h[(n-r) \bmod N] \omega_N^{kn} \\ &= \sum_{r=0}^{N-1} \sum_{a=0}^{N-1} x[r] h[a] \omega_N^{k(r+a)} \\ &= \left(\sum_{r=0}^{N-1} x[r] \omega_N^{kr} \right) \left(\sum_{a=0}^{N-1} h[a] \omega_N^{ka} \right). \end{aligned}$$

固定 r 后, n 遍历一个周期使 a 也恰遍历一个周期。即使 n 与 $r + a$ 相差 N 的整数倍, $\omega_N^{kN} = 1$ 仍使指数相同。最后两项分别为 $\hat{x}[k]$ 与 $\hat{h}[k]$ 。 ■

于是

$$x * h = \mathcal{F}_N^{-1}(\mathcal{F}_N(x) \odot \mathcal{F}_N(h)). \quad (8.21)$$

若 $\mathbf{C}_h$ 为循环卷积矩阵, 定理对所有 x 成立, 故 $\mathbf{F}\mathbf{C}_h = \text{diag}(\hat{h})\mathbf{F}$, 从而 $\mathbf{C}_h = \mathbf{F}^{-1} \text{diag}(\hat{h})\mathbf{F}$ 。这完整说明 DFT 如何对角化循环卷积: 核的 DFT 系数是各频率模式的特征值。要用它得到完整线性卷积, 两个输入均须补零到

$$N \geq m + r - 1. \quad (8.22)$$

因为所有非零输出索引此时都小于 N , 不会回绕。 $N \geq \max(m, r)$ 只保证装下输入, 不保证装下输出。

整轴频率响应改用 DTFT。若 $h \in \ell_1$ 或具有有限支撑, 即使复指数 $x[n] = e^{i\omega n}$ 自身不在 ℓ_1 中, 仍有绝对收敛的和

$$(x * h)[n] = \sum_r h[r] e^{i\omega(n-r)} = e^{i\omega n} \sum_r h[r] e^{-i\omega r}.$$

输出保持频率, 只乘以

$$H(e^{i\omega}) = \sum_r h[r] e^{-i\omega r}, \quad (8.23)$$

即频率响应 (frequency response)。模长给出放大或衰减, 相角给出该模式的相位变化; 除非相位随频率具有相应线性形式, 不能将所有频率的相位变化都叫同一时间延迟。对 $x, h \in \ell_1$, 绝对可和允许换序, 直接得到

$Y(e^{i\omega}) = X(e^{i\omega})H(e^{i\omega})$ 。同理, 连续 L^1 卷积的傅里叶变换为 $F(\Omega)G(\Omega)$, 其积分换序由前面的绝对积分界保证。

贯穿核的响应为 $H(e^{i\omega}) = 1 - e^{-i\omega}$, 模长为 $2|\sin(\omega/2)|$ 。常量模式 $\omega = 0$ 被消去, 低频缓变被削弱, 较高频的差异更突出; 这解释了它为何是一阶差分, 而有限输入首尾仍受延拓影响。

多通道卷积将标量核换成矩阵核:

$$y_a[n] = \sum_{b=1}^{d_{\text{in}}} \sum_{r \in \mathbb{Z}} H_{a,b}[r] x_b[n-r], \quad a = 1, \dots, d_{\text{out}}. \quad (8.24)$$

各 $H_{a,b} \in \ell_1$ 、各 $x_b \in \ell_1$ 时, 有限通道求和与前述界保证存在性; 有限核则在每个位置作有限计算。相同输入输出通道数且 $\mathbf{H}[r]$ 总是对角矩阵时, 各通道分别滤波, 互不混合; 这不要求各通道在统计上独立。非对角元素则允许输入通道 b 影响输出通道 a 。若采用长度 N 的循环卷积并作 DFT, 频域关系为 $\hat{\mathbf{y}}[k] = \hat{\mathbf{H}}[k]\hat{\mathbf{x}}[k]$; 整轴 DTFT 也有相应的矩阵关系。每个频率上是矩阵乘向量, 需要汇总不同输入通道的贡献。

无时间记忆的特例 $\mathbf{H}[0] = \mathbf{B}$, 其余为零, 只在同一时刻混合通道。取式 (8.2) 中的记录及 $\mathbf{B} = \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}$, 有

$$\mathbf{Y} = \mathbf{X}\mathbf{B}^T = \begin{bmatrix} 1 & 1 \\ 3 & 1 \\ 3 & -1 \end{bmatrix}.$$

如图 8.5 所示, 输出第一通道为和, 第二通道为差, 三个时间位置未变。总能量从 11 变为 22, 因为 $\mathbf{B}^T\mathbf{B} = 2\mathbf{I}$; 用 $\mathbf{B}/\sqrt{2}$ 才保持能量。混合前若两路未按时间对齐, 矩阵计算本身不会修正偏移。

8.3.2.2 线性时变条件下的历史映射

设备增益随时刻变化时, 同样的脉冲在不同时间可能触发不同响应, 线性却仍可成立。用已给定的两时刻核表示

$$\mathbf{y}[n] = \sum_{r \leq n} \mathbf{K}[n, r] \mathbf{x}[r]. \quad (8.25)$$

有限历史窗口中它是有限和; 无限历史中则需另行保证收敛, 例如对有界输入可要求 $\sum_{r \leq n} \|\mathbf{K}[n, r]\| < \infty$ 。求和只取 $r \leq n$ 规定因果性, 矩阵维度仍为 $d_{\text{out}} \times d_{\text{in}}$ 。核事先固定、不随输入改变时, 该表达满足叠加。若同时满足 $\mathbf{K}[n+s, r+s] = \mathbf{K}[n, r]$, 才只依赖滞后 $n-r$, 并可记成固定卷积核; 只因它累加历史, 不能省掉这项条件。




图 8.5 同一双通道三时刻记录的轴与混合。左侧行标记时间、列标记通道；中间矩阵 $\mathbf{B}$ 对每一行对应的同时读数取和与差，右侧时间轴长度仍为 3。通道混合不是时间平移，也不意味着两个输入通道独立；这里只使用当前时刻的值。

例如令 $a[n]$ 在偶数时为 1、奇数时为 2, $y[n] = a[n](x[n] + \frac{1}{2}x[n-1])$ 。它的两时刻核仅在 $r = n, n-1$ 非零，且取值随绝对时刻 n 变化。输入 $\delta[n]$ 在时刻 0 给出 1，将输入延迟一格后，时刻 1 的输出却为 2，而原输出延迟一格在该处仍为 1，因此不平移不变。相反，事先给定 $h[0] = 0$ 、 $h[r] = 2^{-(r-1)}$ ($r \geq 1$) 及负索引为零，就定义了一个有衰减记忆的固定卷积核。对零延拓 $x = (1, 2, 1)$ ，从时刻 0 起的前四项输出为 $(0, 1, 5/2, 9/4)$ ，每次使用相同的滞后权重。

这些例子只需知道输入输出核，不需先引入内部状态。第 13.2.2.1 节将从状态演化构造固定核与两时刻核，并区分初始状态的自由响应、直接项和输入驱动项。那里的有序矩阵乘积解释核从何而来；本节检验的是给定核定义了什么映射。若输出还包含一个与输入无关的非零项，例如初始状态产生的自由响应，总映射一般是仿射映射：线性输出上再加一个固定信号。此时它通常不再满足线性叠加，不能仅因输入驱动部分线性就忽略这一差别。

8.3.2.3 非线性条件下的输入依赖映射

若核参数会根据输入重新计算，那么换一条输入时核也会变。只检查某个固定输入下的矩阵乘法是否线性，不能证明整个输入输出规则线性。最简单的例子是 $(\mathcal{H}x)[n] = x[n]^2$ ：对 $x[n] = 1$ ， $\mathcal{H}(2x)[n] = 4 \neq 2\mathcal{H}x[n]$ ，故不线性。但 $\mathcal{H}(T_r x)[n] = x[n-r]^2 = T_r(\mathcal{H}x)[n]$ ，所以它仍平移不变，且只使用当前值，满足这里的因果性。

再看输入依赖门控

$$y[n] = g(x[n])x[n], \quad g(v) = \frac{1}{1 + e^{-v}}$$

(此例取实数输入)。门控是由当前输入决定的权重。输入 1 与 2 得到的比例分别是 $g(1)$ 与 $g(2)$ ，两者不同，所以 $y(2) \neq 2y(1)$ ；尽管每个位置使用同一规则，叠加仍不成立。对更一般的 $\sum_{r \leq n} K_x[n, r]x[r]$ ，除了检查核如何依赖输入，还要检查计算 K_x 时是否使用了未来值。求和表面上只到 n ，不代表输入依赖的权重一定因果。

可微映射在固定输入附近可以线性化。例如平方映射满足 $(x_0 + \varepsilon v)^2 = x_0^2 + 2\varepsilon x_0 v + \varepsilon^2 v^2$ ，一阶响应是 $v \mapsto 2x_0 v$ 。它依赖作为参照的输入 x_0 ，只描述该输入附近的小扰动；不能据此给全部输入配同一个频率响应。状态参数若由输入选择，也会出现同样边界，具体构造仍回查第 13.2.2.1 节。

8.3.3 基于相关运算的模板比较

卷积叠加输入激起的响应；寻找某个波形出现在哪里，则更自然地把模板与不同片段作内积。采用本章方向约定，**互相关**（cross-correlation）为

$$(x \star h)[n] = \sum_{r \in \mathbb{Z}} x[n+r] \overline{h[r]}. \quad (8.26)$$

固定 n 后，比较的是片段 $r \mapsto x[n+r]$ 与原方向模板 $r \mapsto h[r]$ ；第二个变量取共轭，与前面的内积约定一致。若 $x, h \in \ell_2$ ，Cauchy-Schwarz 保证每个 n 处绝对收敛；有限模板则只需对应片段逐点有定义。

令 $\tilde{h}[r] = \overline{h[-r]}$ ，换元可得

$$(x * \tilde{h})[n] = \sum_s x[s] \overline{h[s-n]} = \sum_r x[n+r] \overline{h[r]} = (x \star h)[n].$$

所以相关可以用共轭反转核的卷积实现，模板自身却按原方向比较。多通道模板在同一 n 处按已声明的通道内积汇总： $\sum_r \sum_c x_c[n+r] \overline{h_c[r]}$ ，带权版本为 $\sum_r h[r]^* W x[n+r]$ 。若归一化，应同时使用当前片段与模板的非零范数，窗口或权重变化也会改变相似性。

仍取零延拓 $x = (1, 2, 1)$ 、 $h = (1, -1)$ 。模板完全在输入内时，相关在 $n = 0, 1$ 得到 $1 - 2 = -1$ 与 $2 - 1 = 1$ ；完整相关在 $n = -1, 0, 1, 2$ 依次为 $(-1, -1, 1, 1)$ 。完整卷积则在 $n = 0, 1, 2, 3$ 得到 $(1, 1, -1, -1)$ ，而 valid 卷积在 $n = 1, 2$ 给出 $(1, -1)$ 。差异既来自核方向，也来自输出索引，不能只看数组长度判断二者相同。许多神经网络库把不反转实核的相关称为“卷积”。从头训练核参数时，可以按库的约定学习这些参数；手算、复用核或推导伴随算子时，仍须明确反转、共轭、延拓及输出范围。

8.3.4 卷积映射的快速计算

计算同一卷积有多种路线。比较速度以前，应先明确要得到完整线性卷积、循环卷积，还是只得到核完全落在已知输入内的一个输出块。对有限序列的多项式 $X(z) = \sum_{i=0}^{m-1} x_i z^i$ 与 $H(z) = \sum_{j=0}^{r-1} h_j z^j$ ，乘积为

$$\begin{aligned} X(z)H(z) &= \sum_{i=0}^{m-1} \sum_{j=0}^{r-1} x_i h_j z^{i+j} \\ &= \sum_{n=0}^{m+r-2} \left(\sum_{i+j=n} x_i h_j \right) z^n. \end{aligned} \quad (8.27)$$

系数恰为线性卷积，多项式的交换律与结合律也解释了有限卷积的相应性质。贯穿例给出

$$P(z) = (1 + 2z + z^2)(1 - z) = 1 + z - z^2 - z^3. \quad (8.28)$$

循环边界则在乘积后取余：

$$(XH) \bmod (z^N - 1) = \sum_{n=0}^{N-1} (x *_N h)[n] z^n, \quad (8.29)$$

这里 x, h 均以长度 N 编码， $z^{N+s} \equiv z^s$ 正好合并回绕项。乘积次数小于 N 时取模不改系数，与补零条件一致。把序列改写成多项式，本身还没有减少计算。要提速，需要利用点值或余数表示，把原来反复使用的系数乘法组织成较少的中间计算。

8.3.4.1 单位根分解下的 FFT 计算

直接求 N 个 DFT 系数需要 $O(N^2)$ 运算，再调用卷积定理并未自动提速。快速傅里叶变换（fast Fourier transform, FFT）是一族快速计算 DFT 的算法，不是另一种频率变换。基二 Cooley-Tukey 分解利用偶数长度的单位根结构复用子结果¹。令 $x_e[r] = x[2r]$ 、 $x_o[r] = x[2r + 1]$ ，它们的 $N/2$ 点 DFT 为 $E[k], O[k]$ 。因为 $\omega_N^2 = \omega_{N/2}$ ，

$$\hat{x}[k] = \sum_{r=0}^{N/2-1} x[2r] \omega_{N/2}^{kr} + \omega_N^k \sum_{r=0}^{N/2-1} x[2r + 1] \omega_{N/2}^{kr}.$$

而 $\omega_N^{N/2} = -1$ ，子变换以 $N/2$ 为周期，所以对 $0 \leq k < N/2$ 有蝶形关系

$$\begin{aligned} \hat{x}[k] &= E[k] + \omega_N^k O[k], \\ \hat{x}[k + N/2] &= E[k] - \omega_N^k O[k]. \end{aligned} \quad (8.30)$$

¹ J. W. Cooley, J. W. Tukey, *An Algorithm for the Machine Calculation of Complex Fourier Series* In *Mathematics of Computation*, 1965, vol. 19, no. 90, pp. 297–301

把奇分支 $O[k]$ 乘以 ω_N^k 以后, 与同一个 $E[k]$ 分别相加和相减, 就得到两个频率格点的结果, 因此并未舍弃后半频率。当 $N = 2^q$ 时, $T(N) = 2T(N/2) + O(N)$, 共 q 层、每层 $O(N)$ 运算, 所以复杂度为 $O(N \log N)$ 。其他合数长度可按其他因子分解, 质数长度也有相应算法; 补到二的幂只是某些实现的便利选择, 不是 FFT 的普遍必要条件。

贯穿例补零到 $N = 4$, 取 $\mathbf{x}_4 = (1, 2, 1, 0)$ 、 $\mathbf{h}_4 = (1, -1, 0, 0)$ 。 $\mathbf{x}_4$ 的偶分支 $(1, 1)$ 的二点 DFT 为 $(2, 0)$, 奇分支 $(2, 0)$ 的为 $(2, 2)$ 。用 $\omega_4 = -i$ 合并得到

$$\hat{\mathbf{x}}_4 = (2 + 2, 0 - 2i, 2 - 2, 0 + 2i) = (4, -2i, 0, 2i).$$

$\mathbf{h}_4$ 的偶、奇分支 DFT 分别为 $(1, 1)$ 与 $(-1, -1)$, 同样得到 $\hat{\mathbf{h}}_4 = (0, 1 + i, 2, 1 - i)$ 。这一步显示如何复用两个二点变换, 而不只是代入四点定义。对 $\mathbf{x}_4$ 逆变换的四个分子依次为

$$4 - 2i + 2i, \quad 4 + 2 + 2, \quad 4 + 2i - 2i, \quad 4 - 2 - 2,$$

除以 4 后恢复 $(1, 2, 1, 0)$, 同时核对了频率顺序、指数符号及归一化。逐点乘积 $\hat{\mathbf{x}}_4 \odot \hat{\mathbf{h}}_4 = (0, 2 - 2i, 0, 2 + 2i)$, 逆 DFT 给出 $(1, 1, -1, -1)$ 。若只用 $N = 3$, 得到的是 $(0, 1, -1)$, 因为末项已经回绕; 再精确的 FFT 也不能把这个循环输出当作原完整卷积。

8.3.4.2 一般选点下的 Toom-Cook 计算

单位根方便递归, 但乘积恢复并不只允许这种选点。Toom-Cook 方法对多项式分块、求值、逐点相乘, 再插值恢复系数。对二次 X 与一次 H , 乘积次数至多为 3, 可使用 $0, 1, -1, \infty$ 四个坐标; 其中“无穷点”表示读取最高次系数, 不是把无穷大传给数值程序²。记

$$\begin{aligned} r_0 &= X(0)H(0), & r_+ &= X(1)H(1), \\ r_- &= X(-1)H(-1), & r_\infty &= x_2 h_1. \end{aligned}$$

设 $P(z) = c_0 + c_1 z + c_2 z^2 + c_3 z^3$, 则 $r_+ = c_0 + c_1 + c_2 + c_3$, $r_- = c_0 - c_1 + c_2 - c_3$, 和、差分别解出偶次与奇次部分:

$$\begin{aligned} c_0 &= r_0, & c_3 &= r_\infty, \\ c_1 &= \frac{r_+ - r_-}{2} - c_3, \\ c_2 &= \frac{r_+ + r_-}{2} - c_0. \end{aligned} \tag{8.31}$$

这是前述插值思想在包含最高次坐标时的具体形式; 分母 2 要求系数域中 2 可逆。

² D. E. Knuth, *The Art of Computer Programming, Volume 2: Seminumerical Algorithms*, Addison-Wesley, 1997, 3rd ed.

贯穿例的四个值为 $(r_0, r_+, r_-, r_\infty) = (1, 0, 0, -1)$ ，恢复为 $(c_0, c_1, c_2, c_3) = (1, 1, -1, -1)$ 。直接展开需 $3 \times 2 = 6$ 次输入系数与核系数相乘，此方案只需四次点值乘法，却增加了求值、插值及常数乘除。长多项式可递归分块获得渐近改进，短核则未必值得；缓存、数据变换和访存也要计入。点值乘法之所以成立，是因为 $P(a) = X(a)H(a)$ ，不是因为任意坐标变换都把乘法变为逐点乘法。

8.3.4.3 互素模分解下的 Winograd 计算

更一般的路线在低次模下先相乘，再用中国剩余定理恢复，因为 $(XH) \bmod m$ 只需 $X \bmod m$ 和 $H \bmod m$ 。Winograd 类算法据此构造较少乘法的乘积或滤波计算，特定输出块还需相应的恢复映射³。先对同一完整乘积取 $M(z) = z^4 - 1 = (z-1)(z+1)(z^2+1)$ 。三个实系数因子两两互素、总次数为 4，分别有

$$P(1) = 0, \quad P(-1) = 0, \quad X \bmod (z^2+1) = 2z, \quad H \bmod (z^2+1) = 1-z.$$

在第三个模下 $z^2 = -1$ ，所以 $XH \equiv 2 + 2z$ 。设恢复的 R 次数小于 4，前两份零余数使 $R(z) = (z^2-1)(az+b)$ 。再模 z^2+1 得到 $R \equiv -2az-2b$ ，与 $2+2z$ 比较便有 $a = b = -1$ ，从而 $R = 1 + z - z^2 - z^3$ 。原乘积次数已经小于 4，因此这正是完整乘积；若次数更高，就只能得到模代表元。本次映射从长度 3 和 2 的输入恢复四项完整卷积，不能直接称作任意输出块的最小算法。

³S. Winograd, *Arithmetic Complexity of Computations*, Society for Industrial and Applied Mathematics, 1980

示例 8.17 可复核的 Winograd $F(2, 3)$ 输出块 固定一维 valid 互相关，输入 $\mathbf{d} = (d_0, d_1, d_2, d_3)^\top$ ，核 $\mathbf{g} = (g_0, g_1, g_2)^\top$ ，所需输出只有

$$\begin{aligned} y_0 &= d_0 g_0 + d_1 g_1 + d_2 g_2, \\ y_1 &= d_1 g_0 + d_2 g_1 + d_3 g_2. \end{aligned}$$

$F(2, 3)$ 使用关于 $z, z-1, z+1$ 的余数与最高次系数坐标。核侧是 $0, 1, -1$ 处点值及最高次系数的缩放；输入侧则针对只恢复两项输出另作线性组合。一组符合本章方向约定的变换为

$$\mathbf{y} = \mathbf{A}^\top [(\mathbf{G}\mathbf{g}) \odot (\mathbf{B}^\top \mathbf{d})], \quad (8.32)$$

其中

$$\mathbf{B}^T = \begin{bmatrix} 1 & 0 & -1 & 0 \\ 0 & 1 & 1 & 0 \\ 0 & -1 & 1 & 0 \\ 0 & 1 & 0 & -1 \end{bmatrix},$$

$$\mathbf{G} = \begin{bmatrix} 1 & 0 & 0 \\ 1/2 & 1/2 & 1/2 \\ 1/2 & -1/2 & 1/2 \\ 0 & 0 & 1 \end{bmatrix},$$

$$\mathbf{A}^T = \begin{bmatrix} 1 & 1 & 1 & 0 \\ 0 & 1 & -1 & -1 \end{bmatrix}.$$

形状分别为 $\mathbb{R}^4 \rightarrow \mathbb{R}^4$ 、 $\mathbb{R}^3 \rightarrow \mathbb{R}^4$ ，逐点相乘后由 $\mathbb{R}^4 \rightarrow \mathbb{R}^2$ 恢复指定输出。为直接核对恒等式，记

$$\begin{aligned} m_0 &= (d_0 - d_2)g_0, \\ m_1 &= \frac{1}{2}(d_1 + d_2)(g_0 + g_1 + g_2), \\ m_2 &= \frac{1}{2}(-d_1 + d_2)(g_0 - g_1 + g_2), \\ m_3 &= (d_1 - d_3)g_2. \end{aligned}$$

则 $m_1 + m_2 = d_2g_0 + d_1g_1 + d_2g_2$ ， $m_1 - m_2 = d_1g_0 + d_2g_1 + d_1g_2$ ，所以 $m_0 + m_1 + m_2 = y_0$ 、 $m_1 - m_2 - m_3 = y_1$ 。

取 $\mathbf{d} = (1, 2, 3, 4)^T$ 、 $\mathbf{g} = (2, -1, 1)^T$ ，有 $\mathbf{B}^T \mathbf{d} = (-2, 5, 1, -2)^T$ 、 $\mathbf{G} \mathbf{g} = (2, 1, 2, 1)^T$ 。四次逐点相乘得到 $\mathbf{m} = (-4, 5, 2, -2)^T$ ，输出变换给出 $(3, 5)^T$ 。直接互相关也有 $2 - 2 + 3 = 3$ 、 $4 - 3 + 4 = 5$ 。六次输入-核乘法减少为四次，但变换的加减和常数运算仍有成本。

三条路线共同利用乘法兼容的表示，结构却不同。FFT 在 $z^N - 1$ 的全部复单位根处求值，并利用根的规则结构快速变换；Toom-Cook 允许一般选点及递归分块；Winograd 类构造用互素余数并常针对指定小块输出。模多项式都是一次因子时，中国剩余定理中的余数就是点值，因而与点值插值相同。若包含高次因子，其余数是一个低次多项式，不能再当作单个点值。

长度相近的两个 n 项序列直接卷积需要 $O(n^2)$ 次乘加，FFT 路线在合适长度上需 $O(N \log N)$ 变换运算及 N 次频域乘法。乘法数和渐近量级并非完整运行时间：加减、复数算术、常数运算、缓存复用与目标硬件都会改变实际排序。归一化 DFT 是酉变换、条件良好，但多层蝶形仍会累积舍入

误差；Toom–Cook 和 Winograd 的变换矩阵可能有较大尺度差异，相近量相减也会放大相对误差。

整数或有限域算法还要检查系数域条件。一个有限域（finite field）的例子是模素数 p 的数系：只保留 $0, \dots, p-1$ ，加乘后取模，非零元素都有乘法逆元。例如模 5 时 $2 \cdot 3 = 1$ ，所以除以 2 就是乘以 3。数论变换（number-theoretic transform, NTT）在这类数系中按 DFT 的形式求值；它需要所需阶数的单位根，逆变换中的 N 也须可逆。若 p 整除 N ， N 在该数系中就是零，不能作为除数；前面 Toom–Cook 的除以 2 也有同样的系数域限制。

若目标是恢复整数系数，还要从有限域运算返回整数余数重构。此处的模数是整数，与前面的模多项式不同。设总整数模数为 Q （使用多个两两互素模数时取它们的乘积），选取区间 $(-Q/2, Q/2]$ 内的余数代表。已知每个真实系数绝对值不超过 B 时， $Q > 2B$ 保证该代表唯一等于真实系数：两个候选系数之差绝对值至多 $2B$ ，不可能是非零的 Q 倍数。第 n 个卷积系数的绝对值可由 $\sum_{i+j=n} |x_i h_j|$ 控制，再对输出位置取统一上界即可选取 B 。避免浮点误差并不等于避免模混淆或整数溢出。没有脱离规模、数据类型和误差目标的普遍最优算法。

选择快速算法时，仍须核对要计算的映射：FFT 线性卷积要满足补零条件，Toom–Cook 恢复所设多项式乘积，网络互相关要另行核对核方向；Winograd 只恢复设计的输出块，步长、空洞率或边界变动后要重新推导。快速算法改变的是计算顺序。它不会增加输入信息，边界条件仍需由所求问题确定。

8.4 信号的采样与恢复

传感器每秒记录一次温度；即使准确保存了全部读数，两次记录之间也可能发生未被读到的变化。完整 DFT 能恢复这些读数，却不能据此恢复产生读数的任意连续信号。采样只读取一些位置，可能把不同信号映为相同数据；重构必须靠额外的信号类约束排除这种歧义。本节先说明何种区别在采样时消失，再给出带限条件下的恢复定理，最后区分精确恢复与采样前主动改变频率内容的预滤波。

8.4.1 采样映射与混叠歧义

固定时间原点及采样间隔 $T_s > 0$ ，对具有确定点值的连续时间信号 f 读取 $x[n] = f(nT_s)$ ，采样频率为 $\nu_s = 1/T_s$ 。若不约束候选信号，采样通常不是单射。例如 $T_s = 1$ 时， $f_1(t) = \cos(0.8\pi t)$ 与 $f_2(t) = \cos(1.2\pi t)$ 频率不同，却满足

$$f_2(n) = \cos(2\pi n - 0.8\pi n) = \cos(0.8\pi n) = f_1(n), \quad n \in \mathbb{Z}.$$

这是混叠 (aliasing): 不同连续振荡在样本上无法区分。图 8.6 中的两条曲线在样本之间起伏不同, 但每个整数位置都穿过同一点。




图 8.6 教学构造 $f_1(t) = \cos(0.8\pi t)$ 与 $f_2(t) = \cos(1.2\pi t)$ 。蓝色实线和红色虚线在整数时刻具有共同样本, 深灰圆点标出这些观测。图只展示 $[0, 5]$, 样本相同对所有整数成立; 两条纯余弦是功率信号, 不属于后文定理中的整轴平方可积信号类。

任何确定性插值器对相同输入样本只能返回同一输出, 因此不可能同时正确恢复这两条曲线。学习模型可以凭训练分布猜测更常见的细节, 但这种能力来自额外先验, 不是样本自身包含了两次采样之间的全部信息。图中的纯余弦有有限平均功率, 整轴能量却为无穷; 后文将改用 L^2 带限空间, 所以此例只用于说明混叠, 不能当作该空间内恢复定理的反例。对一般 L^2 等价类, 点值采样本身还未定义, 下一小节会先补齐代表元条件。

离散信号也可以丢弃位置。对正整数 M 保留每 M 项中的一项, $y[n] = x[Mn]$, 称为 M 倍下采样 (downsampling)。其 DTFT 满足

$$Y(e^{i\omega}) = \frac{1}{M} \sum_{\ell=0}^{M-1} X(e^{i(\omega+2\pi\ell)/M}). \quad (8.33)$$

对 $x \in \ell_1$, 按定义展开右侧并交换有限和与绝对收敛级数,

$$\begin{aligned} \frac{1}{M} \sum_{\ell=0}^{M-1} X(e^{i(\omega+2\pi\ell)/M}) &= \sum_{r \in \mathbb{Z}} x[r] e^{-ir\omega/M} \left(\frac{1}{M} \sum_{\ell=0}^{M-1} e^{-2\pi i \ell r/M} \right) \\ &= \sum_{n \in \mathbb{Z}} x[Mn] e^{-i\omega n}. \end{aligned}$$

括号内的单位根和只在 $M \mid r$ 时为 1, 否则为 0, 故留下的恰为输出 DTFT。对 $x \in \ell_2$, 下采样满足 $\sum_n |x[Mn]|^2 \leq \sum_r |x[r]|^2$, 频域右侧的有限分支映射在 L^2 中也有界; 先对有限截断证明再取 L^2 极限, 便得到同一公式的等价类解释。

输入模式 $e^{i\omega_0 n}$ 变为 $e^{iM\omega_0 n}$ ，输入频率映到 $M\omega_0 \bmod 2\pi$ 。原频谱沿输出频率轴扩展 M 倍，超出主值区间的部分回绕，与其他分量相加。所以“样本点变少”不只是频率曲线画得稀疏，而可能直接合并原来不同的频率。连续采样的频谱复制也有类似现象，但必须在可读取点值的信号类上推导。

8.4.2 信号约束下的恢复与预滤波

排除歧义有两种不同做法：限制原信号本来就属于可恢复的类，或者先改变原信号，使准备保留的部分适合新的采样间隔。前者讨论从原信号样本精确恢复，后者讨论采样前删掉或压低哪些分量，恢复目标也随之改变。

8.4.2.1 带限条件下的精确恢复

刚才的两条曲线之所以无法区分，是因为两种不同频率都可以作为候选。如果事先知道原信号不含超过某个上限的频率，就有可能排除其中一种解释。这种条件称为带限，限制的是候选信号的频率内容，而不是观察时长。

定义 8.18 平方可积带限信号 设 $\Omega_{\max} > 0$ 、 $f \in L^2(\mathbb{R})$ ，其 Plancherel 意义的傅里叶变换为 F 。若 $F(\Omega) = 0$ 对几乎处处的 $|\Omega| > \Omega_{\max}$ 成立，称 f 带限于 $\Omega_{\max}$ 。所有这类函数组成 Paley-Wiener 带限空间。

只观察一个有限时间窗口，不能推出窗口外为零，更不能推出高频为零。带限才是下面用来排除混叠的信号类条件。

带限还使点值有规范含义。由 $F \in L^2$ 及频谱支撑长度有限，Cauchy-Schwarz 不等式给出

$$\|F\|_1 \leq \sqrt{2\Omega_{\max}} \|F\|_2 < \infty.$$

因此

$$f_c(t) = \frac{1}{2\pi} \int_{-\Omega_{\max}}^{\Omega_{\max}} F(\Omega) e^{i\Omega t} d\Omega$$

是 f 的连续代表元；连续性由以 $|F|$ 为可积控制函数的控制收敛得到。两个连续代表元若几乎处处相等，就处处相等，所以这种选择唯一。以下仍记它为 f ，样本 $f(nT_s)$ 都针对这个代表元，不针对随意改过点值的版本。

记采样角频率 $\Omega_s = 2\pi/T_s$ ，基带 $I_s = [-\pi/T_s, \pi/T_s]$ 。这里基带 (base-band) 指选定的一段基本频率区间。要判断采样是否把不同频率混在一起，

下一步需要写出样本频谱与原频谱的关系。先把原频谱按间隔 Ω_s 平移并相加,

$$P_F(\Omega) = \frac{1}{T_s} \sum_{k \in \mathbb{Z}} F(\Omega - k\Omega_s).$$

由于 F 带限, 在 I_s 上只有有限多个平移副本可能非零, 故 $P_F \in L^2(I_s)$, 并以 Ω_s 为周期。采用基 $e^{-i\Omega n T_s}$, 其第 n 个傅里叶系数为

$$\begin{aligned} \frac{1}{\Omega_s} \int_{I_s} P_F(\Omega) e^{i\Omega n T_s} d\Omega &= \frac{1}{2\pi} \int_{\mathbb{R}} F(\Omega) e^{i\Omega n T_s} d\Omega \\ &= f(nT_s) = x[n]. \end{aligned}$$

第一步令 $u = \Omega - k\Omega_s$, 各平移区间拼回实轴, 且 $e^{inT_s k\Omega_s} = e^{2\pi i n k} = 1$; 第二步就是所选连续代表元的逆变换。由周期 Parseval 关系, 系数序列 x 属于 ℓ_2 , 故样本的频率表示 $X_s(\Omega) = \sum_n x[n] e^{-i\Omega n T_s}$ 在 $L^2(I_s)$ 中有定义。它与 P_F 的全部系数相同, 得到

$$X_s(\Omega) = \frac{1}{T_s} \sum_{k \in \mathbb{Z}} F(\Omega - k\Omega_s). \quad (8.34)$$

这也就是 DTFT 在 $\omega = \Omega T_s$ 下的写法。采样不是只保留一份原频谱, 而是周期复制再叠加。以上推导只用带限空间、傅里叶级数和积分, 不需把采样写成 Dirac 脉冲列乘积; 若采用后者, 则要另行建立广义函数的乘积与变换规则。

当 $\Omega_s > 2\Omega_{\max}$ 时, 邻近副本不重叠, 基带内只有中央副本。当 $\Omega_s < 2\Omega_{\max}$ 时, 允许频带与其平移副本在正测度区间重叠, 整个带限空间上的采样不再单射: 可在频带内选择小区间 J , 使 J 和 $J + \Omega_s$ 都留在频带中且不相交; 在 J 上放任意非零 L^2 频谱, 在 $J + \Omega_s$ 上放其负平移, 两份周期复制相消, 于是非零信号的全部样本为零。临界 $\Omega_s = 2\Omega_{\max}$ 仅在端点相接, 零测端点不改变当前 L^2 等价类, 不能把它与正测度重叠一概而论。

定理 8.19 带限信号的采样重构 若 f 属于上述 Paley-Wiener 空间, 频谱支撑包含于 $[-\Omega_{\max}, \Omega_{\max}]$, 且 $\Omega_s > 2\Omega_{\max}$, 则全部样本 $f(nT_s)$ 唯一确定 f , 并有

$$f(t) = \sum_{n \in \mathbb{Z}} f(nT_s) \operatorname{sinc}\left(\frac{t - nT_s}{T_s}\right), \quad \operatorname{sinc}(u) = \frac{\sin(\pi u)}{\pi u}, \quad (8.35)$$

其中 $\operatorname{sinc}(0) = 1$ 。对称部分和在 $L^2(\mathbb{R})$ 中收敛, 并对所选连续代表元在整条实轴上一致收敛。

证明. 条件保证 F 的支撑严格落在 I_s 内, 频谱复制式在该区间上给出 $F = T_s X_s$ 。因此 F 相对于 $e^{-i\Omega n T_s}$ 的傅里叶系数是 $T_s f(n T_s)$, 部分和

$$F_K(\Omega) = T_s \sum_{n=-K}^K f(n T_s) e^{-i\Omega n T_s}$$

在 $L^2(I_s)$ 中趋于 F 。把 F_K 在 I_s 外取零, 逆变换的有限和可移入积分外:

$$\begin{aligned} f_K(t) &= \sum_{n=-K}^K f(n T_s) \frac{T_s}{2\pi} \int_{-\pi/T_s}^{\pi/T_s} e^{i\Omega(t-nT_s)} d\Omega \\ &= \sum_{n=-K}^K f(n T_s) \operatorname{sinc}\left(\frac{t-nT_s}{T_s}\right). \end{aligned}$$

对 $t \neq n T_s$, 指数积分是 $2 \sin(\pi(t-nT_s)/T_s)/(t-nT_s)$; 当 $t = n T_s$ 时, 积分为区间长度 $2\pi/T_s$, 乘上 $T_s/(2\pi)$ 后才等于 1。这与 $\operatorname{sinc}(0) = 1$ 的连续延拓一致。Plancherel 等式给出 $\|f_K - f\|_2 = (2\pi)^{-1/2} \|F_K - F\|_2 \rightarrow 0$, 从而得到 L^2 重构。

由于误差频谱仍支持在 I_s 内, 逐点误差还满足

$$\sup_{t \in \mathbb{R}} |f_K(t) - f(t)| \leq \frac{1}{2\pi} \|F_K - F\|_{L^1(I_s)} \leq \frac{\sqrt{|I_s|}}{2\pi} \|F_K - F\|_{L^2(I_s)} \rightarrow 0.$$

这证明整轴一致收敛。所用关键是有限频谱支撑, 不能把这项结论直接套到任意周期 L^2 函数的逐点傅里叶展开。

若两条满足条件的信号样本相同, 则频谱在 I_s 上的所有傅里叶系数相同。完备性使两频谱几乎处处相等, 逆变换后得到同一 L^2 元素及同一连续代表元, 因而恢复唯一。 ■

sinc 在整数非零点为零、在原点为一, 所以每个基函数在自己的样本位置给出系数, 在其他样本位置不作贡献。这解释了公式为何插值全部样本, 但仅核对这些点还不能证明样本之间等于原函数; 后者依靠带限性与刚才的唯一性证明。由基带 Parseval 还可得 $\|f\|_2^2 = T_s \sum_n |f(n T_s)|^2$, 说明在当前条件下, 连续能量与离散样本能量只差采样间隔因子。

定理用严格不等号留下频率余量。同一证明可在当前 L^2 模型中按几乎处处意义延伸至 $\Omega_s = 2\Omega_{\max}$, 端点相接无碍。若扩大到允许谱线的功率信号, 临界点要另行处理: $\sin(\Omega_{\max} t)$ 在 $T_s = \pi/\Omega_{\max}$ 的全部样本为零, 但它不属于 $L^2(\mathbb{R})$, 因此并不反驳此处结论。

定理使用全部双向无限样本, 理想 sinc 也有无限支撑。有限时长、噪声、未知带宽及非带限分量不会因公式而消失; 有限记录只能支持截断或其他有条件的近似重构, 不能宣称享有同样的无误差保证。把有限窗口外补零还会改变原信号, 不能用这个人为边界代替带限假设。

8.4.2.2 下采样条件下的抗混叠处理

若原信号含有将在抽取后重叠的频率，就应在下采样前限制这些分量，这种预处理称为抗混叠滤波（anti-aliasing filtering）。对 M 倍下采样，理想低通将频率支持限制到 $|\omega| < \pi/M$ 内，使式 (8.33) 中的频谱副本不混在一起。这里恢复的目标是预滤波后的信号，不是已经被滤掉的全部原信号。设计时把希望保留的频段称为通带（passband），把希望压低的频段称为阻带（stopband）；这些名称描述对频率响应的要求，而不表示实际滤波器已经满足要求。

局部平均提供容易计算的平滑，却不自动满足理想低通条件。长度 M 的均值核为 $h[n] = 1/M$ ($0 \leq n < M$)，其余为零。由有限几何级数，

$$H(e^{i\omega}) = \frac{1}{M} \sum_{n=0}^{M-1} e^{-i\omega n} = \frac{1}{M} \frac{1 - e^{-iM\omega}}{1 - e^{-i\omega}},$$

再从分子分母各提出中间相位因子，得到

$$H(e^{i\omega}) = \frac{1}{M} e^{-i\omega(M-1)/2} \frac{\sin(M\omega/2)}{\sin(\omega/2)}. \quad (8.36)$$

当 $\omega \in 2\pi\mathbb{Z}$ 出现 $0/0$ 时，按原有限和取连续值 1。该响应有衰减和零点，却不能将一整段阻带频率都消去。当 $M \geq 3$ 时，在主频率区间 $[-\pi, \pi]$ 内还可看到主峰以外的小峰，称为旁瓣（sidelobes），它们直接显示了高频残留。相位因子反映以当前及过去样本实现均值时的时间对齐；按窗口输出的平均池化（average pooling）可看成这种滤波后抽取。具体地，对同一长度 M 窗口，平均池化和最大池化（max pooling）分别为

$$p_{\text{avg}}[m] = \frac{1}{M} \sum_{r=0}^{M-1} x[Mm + r],$$

$$p_{\text{max}}[m] = \max_{0 \leq r < M} x[Mm + r].$$

若 $y = x * h$ 使用前述因果均值核，则 $p_{\text{avg}}[m] = y[Mm + M - 1]$ ，窗口起点与卷积输出时刻之间有明确的索引偏移。最大池化不满足线性叠加：窗口 $(1, 0)$ 和 $(0, 1)$ 的最大值都为 1，相加后的窗口 $(1, 1)$ 最大值仍为 1，并非两个输出之和 2。因此不能用一个固定线性频率响应完整描述最大池化。

同一两频输入可以比较直接抽取、理想低通和均值预滤波：

$$x[n] = \cos(0.2\pi n) + \cos(0.8\pi n).$$

直接二倍抽取得到 $x[2m] = 2 \cos(0.4\pi m)$ ，因为 1.6π 与 -0.4π 在整数位置对应相同余弦。若先理想低通完全删除 0.8π 分量，输出则为 $\cos(0.4\pi m)$ 。若仅用 $h = (1/2, 1/2)$ ，恒等式

$$\frac{\cos(\omega n) + \cos(\omega(n-1))}{2} = \cos(\omega/2) \cos(\omega n - \omega/2)$$

表明抽取后为

$$\cos(0.1\pi) \cos(0.4\pi m - 0.1\pi) + \cos(0.4\pi) \cos(1.6\pi m - 0.4\pi).$$

第二项仍折回低频，只是幅度降低并发生相位偏移。均值滤波在原高频处的残留幅度为

$$|H(e^{j0.8\pi})| = \cos(0.4\pi) > 0,$$

所以它没有清除这个高频。这些纯余弦用于按模式计算频率响应，是功率信号算例，不把它们误放进前述 L^2 恢复定理。“已经平滑”与“满足无混叠带限条件”因此不是同一个保证。

有限长度核的频率响应是有限个复指数的线性组合，也称三角多项式。若在一整段频率上精确为零，就会迫使对应多项式恒为零。因此，非零有限核不能精确实现通带全部通过、阻带全部为零的理想低通。实际设计通常允许通带与阻带之间留出一段缓变的过渡带（transition band）。通带误差衡量保留频段的响应偏离目标多少，阻带衰减衡量抑制频段还剩多大幅度；它们需要与过渡带宽度、延迟及计算量一起规定。滤波后剩余的混叠是设计误差的一部分，不能因用了低通名称就忽略。如果响应在某频段为零，该频段进入映射零空间；接近零的响应虽可能形式可逆，反演却会放大噪声。第 6 章的零空间与小奇异值分析在这里仍然适用：前者说明哪些输入区别完全不可见，后者说明哪些区别虽可见却难以稳定恢复。

8.5 本章小结

分析信号先要确定在哪里取值、每个位置有几个通道，以及首尾如何连接。有限记录不等于有限支撑，通道数不等于时间长度，周期延拓也不等于原过程周期。内积规定哪些位置与通道参与比较，范数衡量峰值或累计大小，能量累计幅值平方，平均功率则适合长期持续的信号；改变通道权重或观察窗口，比较的对象也随之改变。

脉冲、傅里叶和多项式表示从不同方向描述同一信号。完整有限 DFT 及满足次数条件的插值可以无损恢复坐标，无穷傅里叶展开则需要说明积分、均方或逐点意义。幅度不包含全部位置信息，Parseval 中的尺度因子来自归一化，截断系数才引入相应的表示误差。

平移、反转、幅值及时间缩放改变的是不同属性。对有限支撑输入，线性与平移不变使各位置触发的脉冲响应叠加成卷积；推广到无穷输入时，还需有界性或可积条件。时变核可以线性却不只依赖滞后，输入门控则通常破坏叠加；多通道矩阵核还须分清时间汇总与通道混合。相关按原模板方向比较局部片段，不能只凭实现名称把它与卷积混同。FFT、Toom-Cook 和 Winograd 用不同表示减少同一目标的计算，核方向、边界、输出范围及数值条件仍由目标决定。

采样改变了可用信息。不同信号可能具有同一样本，坐标可逆和计算快速都不能补回已经消失的区别。若信号带限且能量有限，选择它唯一的连续代表元，再按足够密的间隔取得全部双向无限样本，就可以用 sinc 公式恢复；有限记录 and 功率信号需要各自核对边界。抗混叠预滤波可以控制即将重叠的频率，却也改变待恢复的目标。下一章把规则索引推广为一般图：连接关系决定哪些位置可以比较与传播，图上的谱则提供相应的变化坐标。后面的随机变量部分描述观测中的不确定性；第 13 章再增加内部状态，解释响应核怎样从演化规律产生。本章保留的输入输出视角则继续用于判断这些响应怎样作用于信号。

图的表示与计算

把四个变量之间的局部约束画成一张图以后，我们可以问：两点之间有没有路径，哪些变量可以分开计算，怎样找到成本最小的方案并证明它确实最优？若在每个顶点再放一个数，沿边汇总又会保留或抹去哪些差异？这些问题使用同一张图的连接关系，却需要不同的计算规则。本章把图本身作为研究对象，利用已有的集合、逻辑与线性代数工具，建立路径查询、结构分解、离散选择及图上函数的运算。后续第12章再说明图怎样表达生成机制，以及什么条件下图分离能够推出概率独立。本章先回答图上哪些路径可通过、哪些顶点可分块计算；这些结论不需要先指定概率模型。至于沿边传递局部结果能否得到精确答案，还须检查局部函数怎样组合，以及采用什么汇总运算。

继续使用第2章的四个二值变量

$$z_i \in \{0, 1\}, \quad i \in V = \{1, 2, 3, 4\}.$$

式(1.12)的前两个子句共同涉及 z_1, z_2 ，第三个子句涉及 z_1, z_3 ，三变量子句 $\neg z_4 \vee z_2 \vee z_3$ 则同时涉及 z_2, z_3, z_4 。把共同出现的每一对变量连接，得到

$$E = \{\{1, 2\}, \{1, 3\}, \{2, 3\}, \{2, 4\}, \{3, 4\}\}. \quad (9.1)$$

图9.1中，左右两个三角形共享顶点2,3。固定这两个变量以后，左右两侧的局部计算可以分别进行；但三元子句仍须保留，三条两两连接并没有把它变成三个等价的二元约束。

我们先明确顶点和边表示什么，再用路径与遍历判断哪些点能相互到达。若两部分之间只通过少数共享变量联系，就可以把这些变量作为接口，组织分块计算。删去冗余边和消去变量也能简化问题，但需要分别检查它们保留了什么。加入边长、容量或标签成本以后，才有相应的最优选择问题。讨论图上的函数时，还须分清：给每个顶点一个数，与给全部变量的一次完整赋值一个数，所需运算并不相同。给顶点数值换坐标或滤波，处理的是图信号；汇总所有变量的赋值，处理的是配置查询。前章的变换与卷积推广到图上时，也要先说清楚现在处理哪一种函数，再选择相应运算。




图 9.1 由四变量约束的作用域导出的关系图。边表示两个变量共同出现在至少一个约束中；共享顶点集合 $\{2, 3\}$ 连接左右两侧。图没有记录约束的具体真值表，也没有预先指定边长、容量或相似度。

9.1 图的对象与表示

画一条线之前，需要说明它记录的是对称关系、有方向的作用，还是某个多变量函数的作用域，也就是这个函数同时依赖哪些变量。确定对象以后，邻接表与矩阵才是同一结构的不同存储方式；改变顶点编号也不应改变结构本身。这里固定这些约定，路径、优化和传播再分别使用它们。

9.1.1 局部关系的对象与作用域

9.1.1.1 二元关系的图表示

若只需记录哪些对象直接相关，可以让每个对象对应一个顶点，让一对对象的关系对应一条边。无向图 (undirected graph) 是 $\mathcal{G} = (V, E)$ ，其中 V 是有限顶点集合， E 是不同顶点的无序对集合。本章默认没有自环，也没有同一对顶点之间的平行边；允许这些情形时，要另外保存边的身份及重数，不能继续把边集理解成普通无序对集合。

若 $\{i, j\} \in E$ ，称 i, j 相邻，二者互为邻居。顶点 i 的邻域 (neighborhood) 是它的全部邻居，度 (degree) 是邻居的数量：

$$N(i) = \{j \in V : \{i, j\} \in E\}, \quad d_i = |N(i)|.$$

贯穿图中 $N(2) = \{1, 3, 4\}$ 、 $d_2 = 3$ ，而 $N(1) = \{2, 3\}$ 、 $d_1 = 2$ 。度只统计直接连接，不统计经过其他顶点能够到达的对象。

关系具有方向时，使用有向图 (directed graph) $\mathcal{G} = (V, A)$ ，其中 $A \subseteq V \times V$ 是有序对的集合，并仍排除 (i, i) 。弧 (i, j) 写作 $i \rightarrow j$ ，不自动包含反向弧。入邻域 $N^-(j) = \{i : i \rightarrow j\}$ 记录哪些顶点直接指向 j ，出邻域 $N^+(j) = \{i : j \rightarrow i\}$ 记录 j 直接指向哪些顶点；它们的大小称为入度 (in-degree) 和出度 (out-degree)。有向图中也常把入邻居称为父节点，把出邻居称为子节点。这些名称只说明连接方向；有向边可以表示计算依赖，也可以表示道路允许通行的方向；具体含义由问题指定，仅有箭头不足以说明改变起点就会造成终点变化。

在结构边上还可以指定权重 (weight)，即每条边附带的数值。无向权重满足 $w_{i,j} = w_{j,i}$ ，有向权重允许方向不同。有向与无向描述方向，加权与无权描述是否附带数值，是能够组合的两个属性。边长越大表示经过它的成本越高，容量越大表示允许通过的总量越多，相似度越大则通常表示两端越接近；同一个数字不能未经转换同时充当这三种量。

结构存在也不等于权重非零。本章允许零权结构边，另把无向非负权图中的

$$E_+ = \{\{i, j\} \in E : w_{i,j} > 0\}$$

称为正权支撑 (positive-weight support)。例如两顶点之间存在一条权重为零的边，结构上仍相邻，但在线性加权汇总中互不贡献。因此后面的谱与扩散结论使用支撑图 $\mathcal{G}_+ = (V, E_+)$ ，而结构路径查询是否使用零权边，要由查询规则另行决定。

若只研究部分顶点，但希望保留它们在原图中的全部直接关系，可以取诱导子图。给定 $U \subseteq V$ ，保留 U 及原图中两端都属于 U 的全部边或弧，所得图称为诱导子图 (induced subgraph)，记作 $\mathcal{G}[U]$ 。贯穿图在 $\{1, 2, 3\}$ 上的诱导子图必须保留三条边；只留下 $1-2-3$ 是一个子图，却不是该顶点集上的诱导子图。

9.1.1.2 高阶关系的因子表示

三元子句 $\neg z_4 \vee z_2 \vee z_3$ 要求同时查看三个变量。这种局部函数称为因子 (factor)，它依赖的变量集合称为作用域 (scope)。要保留“共同属于同一个因子”的信息，可以使用超图 (hypergraph)：每条超边是一个顶点子集，不限于两个顶点；超边 $\{2, 3, 4\}$ 在这里记录三元作用域。函数值仍须另外保存，超边本身也不是约束真值表。

另一种表示把变量和因子分成两组，只在变量属于因子作用域时连边。两组顶点内部都没有边的图称为二部图 (bipartite graph)；这样得到的因子图 (factor graph) 用方形顶点保存因子的身份，用圆形顶点保存变量。若只保留变量，并把每个因子作用域内的变量两两相连，得到原始关系图 (primal graph)，也简称原始图。贯穿图正是按这条规则由原子句得到的。

图 9.2 比较两种表示。一个三元因子和三个二元因子可以产生同一个三角形原始图，但它们能够表达的约束一般不同。例如二值三元约束“恰有偶数个变量等于 1”允许 000, 011, 101, 110。每一对变量的四种取值都在某个允许配置中出现；若只保留这三个二元允许关系，它们便不再排除任何配置，错误地允许了 001。三元约束要求三个取值共同满足条件，只保留两两允许关系就会丢掉这个要求。




图 9.2 三元因子与原始关系图。左侧方框是同一个依赖 z_2, z_3, z_4 的函数，连线表示作用域归属；右侧只保留变量共同出现的两两关系。右侧三条边不是把三元函数分解成三个二元函数的等价变换，也不能恢复原函数的数值。

9.1.2 图关系的矩阵表示

不同计算需要读取不同信息：遍历要快速找到邻居，线性汇总要计算矩阵与向量的乘积，边差分则要逐边取得两个端点的值。邻接表、邻接矩阵和关联矩阵分别直接支持这三种操作。邻接表为每个顶点存实际邻居及其边属性，空间为 $O(|V| + |E|)$ ；无向边在两个端点各存一次只改变常数。稠密邻接矩阵则为每一对顶点预留一个位置。

固定顶点次序 $1, \dots, n$ ，邻接矩阵（adjacency matrix） $\mathbf{A} \in \mathbb{R}^{n \times n}$ 的条目为

$$a_{i,j} = \begin{cases} w_{i,j}, & \{i,j\} \in E \text{ 或 } (i,j) \in A, \\ 0, & \text{其他情形.} \end{cases}$$

无权边取权重 1。有向情形约定行是起点、列是终点，因此 $(\mathbf{A}\mathbf{f})_i = \sum_{j \in N^+(i)} w_{i,j} f_j$ 汇总出邻居的值；若要把每个起点的值沿出弧发送到终点，应使用 $\mathbf{A}^\top \mathbf{f}$ 。无向图中矩阵对称，两种读法才重合。贯穿图对应

$$\mathbf{A} = \begin{bmatrix} 0 & 1 & 1 & 0 \\ 1 & 0 & 1 & 1 \\ 1 & 1 & 0 & 1 \\ 0 & 1 & 1 & 0 \end{bmatrix}. \quad (9.2)$$

例如 $\mathbf{f} = (1, 2, 3, 4)^\top$ 给出 $\mathbf{A}\mathbf{f} = (5, 8, 7, 5)^\top$ 。这是顶点值的线性汇总，不等于在全部变量配置上求和；后者还需要明确局部因子。允许零权边时，矩阵条目 0 不能区分无边与零权边，必须另存边集或结构掩码 $m_{i,j} = \mathbb{I}\{\text{存在相应结构边}\}$ 。

要计算每条边两端的差，给每条无向边任选临时方向，构造关联矩阵（incidence matrix） $\mathbf{B} \in \mathbb{R}^{|V| \times |E|}$ 。边 $e : i \rightarrow j$ 对应列在 i 处取 1，在 j 处取 -1，其余为零。于是 $(\mathbf{B}^\top \mathbf{f})_e = f_i - f_j$ 。若 $\mathbf{W}_E = \text{diag}(w_e : e \in E)$ ， $\mathbf{B}\mathbf{W}_E\mathbf{B}^\top$ 先求边差、按权缩放，再汇总回顶点。反转某些临时方向相当于 $\mathbf{B}' = \mathbf{B}\mathbf{R}$ ，其中 $\mathbf{R}$ 为对角元取 ± 1 的对角矩阵。由于 $\mathbf{R}\mathbf{W}_E\mathbf{R} = \mathbf{W}_E$ ，这个无

向加权差分算子不随临时方向改变。这并没有消除真正有向图中的方向，二者不能混用。

9.1.3 顶点重编号下的结构同一性

矩阵的位置依赖编号，图的连接关系却不应依赖编号。两图 $\mathcal{G} = (V, E)$ 、 $\mathcal{G}' = (V', E')$ 若存在双射 $\rho: V \rightarrow V'$ ，使

$$\{i, j\} \in E \iff \{\rho(i), \rho(j)\} \in E',$$

就称为同构 (isomorphic)：忽略顶点名称后，两图的连接完全相同。对有向图，重编号必须保留每条弧的起点与终点关系；对加权图，还要保留对应边权。若顶点或边另有属性，也须说明同构要求保留哪些属性。设置换矩阵满足 $(\mathbf{P}\mathbf{f})_{\rho(i)} = f_i$ ，重编号对应

$$\mathbf{A}' = \mathbf{P}\mathbf{A}\mathbf{P}^\top. \quad (9.3)$$

矩阵左右分别乘置换矩阵及其转置，只把行列移到新编号对应的位置，不会把不同顶点的值混合。第 6 章的一般相似变换允许混合坐标，所以不能把任意换基都解释成图重编号。

若想只用邻接矩阵判断同构，还须保证矩阵能区分哪些边存在。无权图或所有结构边权非零时，式 (9.3) 给出矩阵判据；允许零权结构边时，还须验证 $\mathbf{M}' = \mathbf{P}\mathbf{M}\mathbf{P}^\top$ 。两顶点空图与两顶点零权单边图都可有 $\mathbf{A} = \mathbf{0}$ ，但前者不相邻、后者相邻。

同构必有相同邻接谱，因为置换共轭是相似变换；逆命题不成立。例如四叶星图 $K_{1,4}$ 与“四环加一个孤立顶点”都有邻接特征值 $2, -2, 0, 0, 0$ 。前者的非零特征值来自中心与四个叶顶点的汇总，后者的四环特征值为 $2, 0, 0, -2$ ，再加孤立点的零值。一图连通、另一图不连通，故不同构。这里比较的是邻接谱；后文不同算子的谱也必须指明算子，不能只说“两个图的频率相同”。图上顶点函数随编号怎样变化，将在第 9.5.1 节用这里的置换关系检验。

9.2 图上的关系、路径和遍历

顶点不相邻，并不表示二者毫无联系：关系可以经其他顶点延伸。本节从一条边扩展到一条路径，再区分“存在某条路径”“所有路径都被阻断”和“找到代价最小的路径”。遍历负责检索这些对象；加权最优选择所需的额外条件，在第 9.4.1 节集中处理。

9.2.1 两点之间的关系

贯穿图中 1,2 直接相邻, 1,4 不相邻, 但可以通过 2 连接。有向图的直接关系还要看方向: $i \rightarrow j$ 允许一步从 i 到 j , 不能据此反向通行。前面已区分边长、容量与相似度: 现在判断能否通行时, 首先要查是否有边及方向, 再按查询目标使用对应权重。

零边长可以表示免费通行, 零容量表示不能承载正流量, 零相似度则不贡献加权差分。三者都不自动删除结构边。因此“这两个顶点之间能否走一步”应查边集及方向, 不能只检查某个数值矩阵的条目是否大于零。

9.2.2 图上的路径与环

9.2.2.1 行走、简单路径与环

把相邻关系首尾连接得到行走, 也称游走 (walk): 它是顶点序列 $v_0, v_1, \dots, v_k$, 每对相邻项之间都有边, 允许重复顶点和边。若顶点两两不同, 就称为简单路径 (path), 本章无修饰的“路径”默认指简单路径。边数长度为 k , 单个顶点构成长度为零的路径。无向简单图中的环 (cycle) 是长度 $k \geq 3$ 的闭行走, 其中 $v_0 = v_k$, 而 $v_0, \dots, v_{k-1}$ 两两不同。例如贯穿图的 1,2,3,1,2 是行走, 1,2,4 是路径, 1,2,3,1 是环。

有向行走与有向路径 (directed path) 的每一步都必须沿弧方向。有向环 (directed cycle) 除首尾外顶点互异, 并且闭行走的每一步都顺着弧。无自环有向图的环可短至两条弧: $i \rightarrow j \rightarrow i$ 已经成环; 无向图中沿同一条边走去再返回却不是环。不含有向环的图称为有向无环图 (directed acyclic graph, DAG)。这里的“无环”不要求忽略方向后的图也无环, 例如 $1 \rightarrow 2$ 、 $1 \rightarrow 3$ 、 $2 \rightarrow 3$ 构成 DAG, 但底层无向图是三角形。

邻接矩阵的幂可以检索行走, 却不会替我们排除重复顶点。对无权图, $(A^k)_{i,j}$ 等于从 i 到 j 长度为 k 的行走数。当 $k=0$ 时, $A^0 = I$ 记录留在原点的零步行走; 归纳地,

$$(A^{k+1})_{i,j} = \sum_{\ell} (A^k)_{i,\ell} a_{\ell,j}$$

按倒数第二个顶点 ℓ 分类, 每个长度 $k+1$ 的行走被计数恰好一次。有向图沿行起点、列终点的约定使用同一证明。带权时则有

$$(A^k)_{i,j} = \sum_{i=v_0 \rightarrow v_1 \rightarrow \dots \rightarrow v_k=j} \prod_{r=1}^k w_{v_{r-1}, v_r},$$

无向边可向任一方向行走。这里得到的是权重乘积之和, 不是行走条数, 也不是边长之和。将加法、乘法改成布尔运算或最小加法, 会得到可达性或固定步数的最低成本, 但那已经换了矩阵运算规则。

9.2.2.2 条件集合下的活跃路径

沿箭头可达用于描述依赖方向；另一类查询还要指定顶点集合 S ，检查忽略方向后连接两端的路径是否满足特定的通过规则。这里的 S 只是图查询的输入，不必先为顶点指定随机变量。若从 v 沿长度至少为一的有向路径到达 w ，称 w 为 v 的后代 (descendant)， v 为 w 的祖先 (ancestor)；这两个名称都不包括顶点自身。

定义 9.1 活跃路径与 d-分离的图判据 设 $\mathcal{G}$ 为 DAG。底层路径上的内部顶点 c 若在该路径上呈现 $a \rightarrow c \leftarrow b$ ，称为碰撞点，否则为非碰撞点。给定不含路径端点的顶点集合 S ，该路径活跃 (active)，当且仅当每个非碰撞内部顶点都不在 S 中，且每个碰撞点自身或某个后代属于 S 。

对两两不交的顶点集合 A, B, S ，其中 A, B 非空，若连接 A 与 B 的每条底层路径都不活跃，称 A, B 被 S -分离 (d-separated)，记为 $A \perp_{\mathcal{G}} B \mid S$ ；否则称为 d-连接。

“碰撞”是相对于当前路径两条相邻弧的角色，同一顶点在另一条路径上可能不是碰撞点。路径是否活跃由箭头与 S 共同决定，并不等于能否沿箭头从起点走到终点。

考虑 $a \rightarrow c \leftarrow b$ 和 $c \rightarrow d$ 。底层路径 $a - c - b$ 在 $S = \emptyset$ 时不活跃，因为碰撞点 c 及其后代都不在 S 中；在 $S = \{c\}$ 或 $S = \{d\}$ 时活跃。后一个条件点甚至不在路径上，却通过“碰撞点有后代被给定”的规则影响路径。相反，在链 $a \rightarrow c \rightarrow b$ 和分叉 $a \leftarrow c \rightarrow b$ 上， c 都是非碰撞点，加入条件 c 会阻断路径。这些都是图判据，不是对任意数值模型自动成立的概率断言。




图 9.3 同一底层路径 $a - c - b$ 在三个条件集下的活跃性。箭头及顶点没有改变；空条件集未打开碰撞点，给定碰撞点 c 或其后代 d 都会打开它。双圈表示被给定的顶点，底部文字给出判定。活跃性不是沿箭头从 a 走到 b 的可达性，也不是简单删除条件顶点后的连通性。

一条路径被阻断还不等于两端被分离，因为另一条路径可能仍活跃。第9.3.1.2节将从单路径规则转向全部路径的查询。

9.2.2.3 路径代价与最短路径

若边的任务是记录长度或代价，记作 $\ell_{i,j}$ ，以免与相似度混淆。从 s 到 t 的路径 $P = (v_0 = s, \dots, v_k = t)$ 的代价为

$$\ell(P) = \sum_{r=1}^k \ell_{v_{r-1}, v_r}.$$

最短路径选择使此和最小的路径。所有边长均为 1 时，它等于最少边数；一般边长下则不等价。例如 $s-t$ 长 5，而 $s-u$ 、 $u-t$ 各长 1，两步路径比一步路径更短。

还须明确是否允许重复经过顶点。有限图只有有限条简单路径，因此只要可达，简单路径代价就有最小值；允许行走时，候选数可以无限。若可从 s 到达一个负代价闭行走，并在那里继续到 t ，反复经过它能使代价任意小。此时行走代价下确界是 $-\infty$ ，却不能说存在一条长度为 $-\infty$ 的简单路径。有向图的负闭行走必包含负有向环；无向负边仅往返一次就产生负闭行走，即使它不在任何无向简单环上。无此负闭行走影响时，可以删去非负闭合段而不增加代价，行走问题才与简单路径问题一致。不可达、负环及距离递推的统一约定稍后给出。

9.2.3 图上的可达与连通

9.2.3.1 无向图的可达与连通

若两点之间存在路径，就称它们互相可达。把可达顶点归在一起，得到连通分量：每个分量内部任意两点可达，不同分量之间没有路径。允许长度为零的路径使每个顶点与自身可达；反向路径给出对称性，拼接两条路径并删去重复段给出传递性，故这些分量确实构成顶点集合的唯一划分。只有一个分量的非空无向图称为**连通** (connected)。

贯穿图连通，删除 $\{1, 2\}$ 仍连通，因为 $1-3-2$ 替代了原有边。删除一个环上的边只破坏该环，不一定破坏连通；是否断开应检查有没有替代路径，而非只数局部少了几条边。

9.2.3.2 有向图的可达与连通

有向可达要求存在顺着弧的路径，所以不再对称。沿用前面的祖先与后代定义，二者均不包含顶点自身。一般有环图中两个不同顶点可以互为祖先，DAG 中则不可能。后文需要保留祖先及起始顶点时，将另用“祖先闭包”表示。

若任意有序顶点对 i, j 间都有从 i 到 j 的有向路径，图称为 **强连通** (strongly connected)；互相可达的极大顶点集合称为强连通分量。忽略弧方向后连通，则称为**弱连通** (weakly connected)。强连通蕴含弱连通，但链 $1 \rightarrow 2 \rightarrow 3$ 仅弱连通：1 可达 3，3 不能返回 1，三个强连通分量各含一个顶点。“两个点属于同一弱连通分量”并没有回答它们能否互相传递。

9.2.3.3 树与森林的连通结构

连通且无环的无向图称为**树** (tree)，若干互不相连的树组成**森林**。树的关键不是画面面向外分叉，而是两点间没有第二条路径。这让一个局部结果沿唯一接口传递，不会从另一条路重复返回。

定理 9.2 树的等价刻画 对含 $n \geq 1$ 个顶点的有限无向简单图，以下三条等价：

1. 图连通且无环；
2. 任意两点之间恰有一条简单路径；
3. 图连通，并且恰有 $n - 1$ 条边。

证明. 连通性保证至少一条路径；若有两条不同路径，沿二者从首次分开处到再次会合处得到一个环，故无环时路径唯一。反过来，路径唯一包含连通性；若有环，环上相邻顶点间既有该边，又有沿环另一侧的路径，与唯一性矛盾。

单顶点树有零条边。至少两个顶点的有限树必有度为 1 的叶顶点：取最长简单路径，它的端点若有路径外邻居，可以延长路径；若与路径上的非相邻顶点相连，则形成环。因此端点只有一个邻居。删除叶顶点及其边后，余图仍连通且无环，归纳得原树边数为 $(n - 1) - 1 + 1 = n - 1$ 。树中每条边又是其两端的唯一路径，删去该边必使两端断开。

最后，设图连通且有 $n - 1$ 条边。从一个顶点开始，每次加入一条连接已加入顶点与未加入顶点的边。只要尚有顶点未加入，连通性就保证有这样的边。每次只接入一个新顶点不会成环，重复 $n - 1$ 次便得到覆盖全部顶点的树。这已经用完原图的 $n - 1$ 条边，故原图就是这棵树，也无环。■

只知道边数为 $n - 1$ 不够：三角形加一个孤立点有四个顶点、三条边，却不是树。从一般连通图抽出一棵覆盖全部顶点的树，需要明确保留连接而舍弃其他边，这将在第 9.3.2.1 节讨论。

9.2.4 图上的遍历与次序

9.2.4.1 广度遍历与分层检索

要列出从 s 能到达的顶点，可以先查一跳邻居，再查两跳邻居。广度优先搜索 (breadth-first search, BFS) 用先进先出队列维持这个次序。初始化时标记 s ，置层数 $d(s) = 0$ ，将它入队。每次取出队首 u ，检查它的邻居；有向图只检查出邻居。遇到尚未标记的 v ，立即标记并入队，置 $d(v) = d(u) + 1$ ，同时记录父指针 $p(v) = u$ 。标记发生在入队时，防止两个已发现顶点把同一个邻居重复入队。

每个顶点最多入队一次，每条边或弧最多检查常数次数，邻接表实现的时间为 $O(|V| + |E|)$ ¹。每个非起点的父指针指向较早发现的顶点，所以不会成环；沿父指针回溯便能恢复从起点到它的发现路径。父边在可达集合上构成搜索树，而不包含原图的全部边。

无权最短路性质由队列分层保证。归纳假设更早层都已经得到正确距离；处理第 k 层时，新发现的邻居有一条长度 $k + 1$ 的路径。若它存在更短路径，该路径的倒数第二个顶点应在更早层，并会更早发现它，矛盾。因此首次记录的层数就是最少边数。贯穿图从 1 出发的层为 $\{1\}, \{2, 3\}, \{4\}$ ，顶点 4 的父亲可以是 2 或 3，但距离同为 2。不同父树不影响层数正确性；一般边长下，层数却不能代替最小总代价。

¹ T. H. Cormen, C. E. Leiserson, R. L. Rivest, C. Stein, *Introduction to Algorithms*, MIT Press, 2022, 4th ed.

9.2.4.2 深度遍历与回路检索

深度优先搜索 (depth-first search, DFS) 沿未探索邻居持续深入，没有新邻居时回退。递归栈或显式栈保存尚未完成的路径；把顶点分成未发现、在栈内、已完成三种状态，就能区分第一次抵达与返回已走过的位置。每点、每边只处理常数次数，邻接表成本同样为 $O(|V| + |E|)$ 。无向图从尚未访问顶点不断重新启动 DFS，可列出全部连通分量；有向图中只这样重启并不能直接求得强连通分量。

在有向图中，弧 $u \rightarrow v$ 若指向当前栈内顶点，则 v 是 u 的祖先，栈内有向路径 $v \rightarrow \dots \rightarrow u$ 连同该弧构成环。反之，若存在有向环，取其第一个被发现的顶点，沿 DFS 完成这个可达区域之前，环上必有一条弧返回尚未完成的环顶点；否则沿环的完成先后关系会循环矛盾。所以有向环存在当且仅当存在这种回边。指向已完成顶点的弧本身不是判环证据。

无向图每条边从两端都被查看，不能把返回父顶点的反向查看当成环。在本章的简单图约定下，跳过父边后，遇到指向栈内祖先的边才构成环：树路径加上这条非父边得到至少三条边的闭合路径。若允许平行边，就须按边身份只跳过那一条父边，不能跳过所有指向父顶点的边。

若有向 DFS 没有回边，对任意弧 $u \rightarrow v$ ，查看时的 v 若未发现，它会作为递归后继先于 u 完成；若已完成，其完成时间本来早于 u ；栈内情形已

被排除。因此每条弧都从较晚完成者指向较早完成者，逆完成次序便是一个符合依赖的处理次序。

9.2.4.3 无环依赖下的拓扑排序

依赖图要求每条弧的起点先于终点处理。满足这一要求的顶点排列称为拓扑序，它把可达关系给出的偏序扩展为线性次序；没有直接边的两点仍可能通过长路径依赖。DFS 已经提供了一个候选构造，下面给出不依赖 DFS 实现的完整判据。

定理 9.3 DAG 的拓扑排序 有限有向图存在拓扑序，当且仅当它不含有向环。拓扑序使每条弧 $i \rightarrow j$ 中的 i 都排在 j 之前。

证明. 若有环 $v_1 \rightarrow v_2 \rightarrow \cdots \rightarrow v_k \rightarrow v_1$ ，次序既要求 v_1 在 v_2 前，依次到 v_k ，又要求 v_k 在 v_1 前，不可能。

反之，非空 DAG 必有入度为零的顶点。否则，从任意点反向追溯入边，总能继续；有限顶点使某点最终重复，重复段按原弧方向构成有向环，矛盾。删除一个零入度顶点及其出弧，余图仍无有向环，可以重复直到图空。每条弧的起点删除后终点才可能入度为零，故删除次序满足拓扑要求。用队列维护新产生的零入度顶点，每点每弧只需检查常数次。 ■

这与 DFS 逆完成次序给出同一存在条件，却不必产生同一个排列。在一个拓扑序中，两个相邻且互相不可达的顶点可以交换位置：它们之间没有依赖，相对于其余顶点的先后关系也没有改变，故仍是拓扑序。这说明拓扑序一般不唯一²。“相邻”不能省略。例如只有边 $a \rightarrow b$ ，另有孤立点 c ， (a, b, c) 是拓扑序；虽然 a, c 互不可达，直接交换它们却得到 (c, b, a) ，破坏了 $a \rightarrow b$ 的次序。下一节将利用连通、路径及接口组织局部结构；这些结构改变是否仍保留原查询，要逐项检查。

² R. Diestel, *Graph Theory*, Springer, 2017, 5th ed.

9.3 图的划分与简化

贯穿图的左右两侧共享顶点 2, 3，不能把它们当作互不相交的两块。合理分块不是把共享部分抹去，而是把它作为接口保留下来。本节先用分隔集和树分解组织局部块，再研究生成树抽取、消元和补弦怎样改变图。这些操作保留的对象不同：保留连通，不代表保留距离；保留计算作用域，也不代表保留原图的全部分离关系。

9.3.1 图的分块与接口

9.3.1.1 基于分隔集的图分块

对两两不交的顶点集合 A, B, S , 其中 A, B 非空, 若从 A 到 B 的每条无向路径都经过 S , 就称 S 将 A 与 B 分隔 (separate)。等价地, 删除 S 及其关联边后, 没有连通分量同时包含 A 与 B 的顶点。若余图的分量为 $C_1, \dots, C_m$, 把接口加回各块, 得到 $\mathcal{G}[C_r \cup S]$ 。这些局部图可在 S 上重叠, 但不同 C_r 之间没有边; 原来横跨局部区域的关系必须经接口传递。

贯穿图中 $S = \{2, 3\}$ 分隔 $\{1\}$ 与 $\{4\}$, 两个局部块为 $\{1, 2, 3\}$ 、 $\{2, 3, 4\}$ 。固定接口赋值后, 两侧因子可以分别计算。只依赖接口的因子则应指定给其中一块, 不能因两个局部块都含这些变量就计入两次。这是局部函数作用域的组织方式, 不论函数表示逻辑约束、成本还是权重, 都可据此分块。若要进一步断言“给定接口以后两侧的随机变量相互独立”, 还须为函数指定相应的概率模型; 后续第12章再建立这种图结构与条件独立的联系。

删除一个顶点后使连通分量数增加, 该顶点称为割点; 删除一条边后使分量数增加, 该边称为桥。贯穿图没有桥, 因为每条边都在一个三角形中, 另有路径连接其两端。它也没有割点: 删去1或4后仍有三角形, 删去2或3后分别留下路径 $1-3-4$ 或 $1-2-4$ 。因此, 剩余顶点在删除任意单点后仍连通, 删除接口的两个顶点2,3后却会断开; 边是不是桥也不能仅凭权重大小判断。

为比较不同图是否给出同样答案, 记 $\mathcal{I}(\mathcal{G})$ 为图的分离关系集合, 元素写作 $(A, B | S)$ 。无向图使用刚定义的分隔, DAG 使用定义9.1中的 d-分离。这个集合只记录图判据, 不包含尚未指定的概率模型。

引理 9.4 分离关系中的邻接判据 在有限无向图或有限 DAG 中, 不同顶点 u, v 相邻, 当且仅当不存在 $S \subseteq V \setminus \{u, v\}$ 能按该图的分离规则分离它们。DAG 中的相邻指任一方向的弧存在。

证明. 相邻两点之间的一步路径没有内部顶点, 任何这样的条件集都不能阻断它。无向图中若不相邻, 取 $S = V \setminus \{u, v\}$ 即可分隔。

DAG 中两点不能互为后代, 不妨令 v 不是 u 的后代, 取 $S = N^-(u)$ 。非邻接保证 $v \notin S$ 。从 u 出发的底层路径若以指向 u 的弧开头, 首个内部顶点是 u 的父节点; 它在此路径上是非碰撞点, 故被 S 阻断。若沿 u 的出弧开头, 因 v 不是后代, 路径必在某处第一次逆着箭头前进。方向切换处是 u 的一个后代碰撞点。该点及其后代都不能属于 $N^-(u)$, 否则存在返回 u 的有向环; 所以这个碰撞点也不会被 S 打开。两类路径都被阻断, 结论成立。■

这说明全部分离查询足以确定哪些顶点直接相邻, 却未必确定箭头方向。要在 DAG 上执行某一次查询, 仍需保留碰撞规则。

9.3.1.2 条件集合下的有向分离

基于活跃路径的分离判定 在 DAG 中, A 与 B 被 S d-分离, 表示每条连接两集合的底层路径都不活跃。找到一条活跃路径足以否定分离; 找到一条被阻断路径却不足以肯定分离。例如 $a \rightarrow c \leftarrow b$ 之外若还有 $a \rightarrow e \rightarrow b$, 即使空条件集关闭了碰撞路径, 链路径仍保持活跃, 故 a, b 不 d-分离。

无向图中增大分隔集只会删除更多路径; DAG 中加入碰撞点或其后代却可能打开路径。因此不能直接删除条件节点后忽略箭头做一次连通检查。后续第 12 章将说明这些图规则的概率与因果含义, 以及从图分离推出条件独立还需要什么模型假设。本节只寻找等价的图查询步骤, 下面的祖先道德化判据也不以概率独立为证明前提。

基于祖先道德化的查询转换 逐条枚举路径不是唯一办法。对当前端点和条件, 只保留它们可能的祖先, 再把共同父节点连起来, 就能把查询转成普通无向分隔。保留祖先是为了筛掉与当前查询无关的顶点; 连接共同父节点则把碰撞规则转成无向连接规则。两步都依赖查询的端点和条件集, 而且必须先筛顶点, 再补边。

定义 9.5 骨架、祖先闭包与诱导祖先图 有向图 $\mathcal{G} = (V, A)$ 的骨架 (skeleton) 记为 $\text{skel}(\mathcal{G})$: 它是同顶点集上的无向图, i, j 相邻当且仅当 $i \rightarrow j$ 或 $j \rightarrow i$ 存在。集合 $U \subseteq V$ 的祖先闭包 (ancestral closure) 为

$$\text{An}_{\mathcal{G}}(U) = U \cup \{v : \text{存在从 } v \text{ 到 } U \text{ 中某点的有向路径}\}.$$

它显式包含 U 本身。 $\mathcal{G}[\text{An}_{\mathcal{G}}(U)]$ 称为诱导祖先图 (ancestral graph)。

记 $\text{pa}(v) = N^-(v)$ 为父集; 图固定时, 也简写 $\text{an}^+(U) = \text{An}_{\mathcal{G}}(U)$ 。父集只走一步, 祖先闭包包含任意多步及自身, 二者不能替换。

定义 9.6 道德图与完美有向图 DAG 的道德图 (moral graph) 记为 $\text{mor}(\mathcal{G})$: 将每个顶点的任意两个不同父节点连成无向边, 再去掉全部弧的方向。这个过程称为道德化 (moralization)。若每个父集在骨架中原本已两两相邻, 称该 DAG 为完美有向图 (perfect directed graph); 此时道德化不新增边。

在 $1 \rightarrow 3 \leftarrow 2$ 中, 全图道德化会补边 $1-2$ 。查询端点 $1, 2$ 且条件集为空时, 祖先闭包却只有 $\{1, 2\}$, 应先删除 3 , 所以查询道德图没有这条边。若给定 3 , 祖先闭包包含三点, 道德化后再删除条件点 3 , 边 $1-2$ 仍在。若给原 DAG 加上 $1 \rightarrow 2$, 父节点已经相邻, 才成为完美有向图。




图 9.4 祖先道德图随查询条件改变。端点固定为 1, 2；空条件集时，查询图只有两个孤立顶点。给定 3 时，先扩大的祖先集合使道德化加入黄虚线 1-2，随后删除灰色条件点及灰点线，却不删除这条新增边。不能先道德化整图再取查询顶点。

定理 9.7 祖先道德化判据 设 $\mathcal{G}$ 为有限 DAG, $A, B, S \subseteq V$ 两两不交, A, B 非空, 并令 $U = \text{an}^+(A \cup B \cup S)$ 。则 A, B 在 $\mathcal{G}$ 中被 S d-分离, 当且仅当它们在 $\text{mor}(\mathcal{G}[U])$ 中被 S 无向分离。

证明. 先设原图有给定 S 时从 A 到 B 的活跃路径。碰撞点都在 $\text{an}^+(S)$ 中；从非碰撞内部点出发，至少能沿路径一侧顺箭头走到端点或碰撞点，故它也是 $A \cup B \cup S$ 的祖先。整条路径因而在 $\mathcal{G}[U]$ 中。属于 S 的内部点只能是碰撞点；把每个片段 $u \rightarrow c \leftarrow v$ 、 $c \in S$ 用道德边 $u-v$ 绕过，便得到避开 S 的无向行走。删去重复段即得无向路径。

反之，取祖先道德图中避开 S 的 $A-B$ 路径。保留骨架边，把每条新增道德边 $u-v$ 展开成 $u \rightarrow c \leftarrow v$ ，其中 $c \in U$ 是共同子节点。展开结果可能重复顶点，暂称为路线。原路径顶点都不在 S 中，新增顶点在插入位置是碰撞点，但路线上的某些碰撞位置可能尚未打开：它们属于 A 或 B 的祖先，却不属于 $\text{an}^+(S)$ 。

对这样的碰撞点 c ，若它本身在 A 或 B ，在该位置截掉相应前缀或后缀，使它成为端点。否则，从 c 顺箭头能到达 $A \cup B$ 中的某点；这条有向路径不经过 S ，否则 $c \in \text{an}^+(S)$ 。终点在 A 时，以该路径的反向行走替换路线从 A 到 c 的前缀；终点在 B 时，以该路径替换从 c 到 B 的后缀。接合处 c 出现向外的弧，不再碰撞，替换段内部也无碰撞。每次至少减少一个未打开的碰撞位置，且不增加新的未打开位置，有限次操作后得到活跃路线。

还须排除重复顶点。取最短活跃路线；若内部顶点 v 重复，删去两次出现之间的段，只有接合处的角色可能改变。若 $v \in S$ ，两次出现原本都须为碰撞，接合后仍为碰撞。若 $v \notin S$ ，唯一风险是接合后形成不在 $\text{an}^+(S)$ 中的新碰撞。出现这个风险意味着，被删段从 v 沿出弧开始，又逆着另一条出弧返回 v 。顺着开始的箭头直到第一次方向反转，必遇到一个作为 v 后代的碰撞点。原路线活跃使该点属于 $\text{an}^+(S)$ ，于是 v 也属于其中，与风险假设矛盾。端点重复时直接截去相应前缀或后缀即可。因此最短活跃路线没有重复点，就是活跃路径。 ■

定理按每次查询构造一张图，并未给出适用于全部条件集的固定无向图。后一问题需要后面建立的弦图与消元次序。

9.3.1.3 基于树分解的局部组织

子图覆盖与接口相容 多个分隔接口要协同工作，同一变量在各块中的副本就必须能沿接口持续传递。只覆盖全部顶点和边不够；若变量在两个远处的块中出现，中间接口却丢了它，两侧就可能作出互不相容的赋值。

先明确哪些集合必须整体容纳。两两相邻的顶点集合称为**团**（clique），全部顶点构成团的图称为**完全图**（complete graph）。不被更大团包含的团称为**极大团**；顶点数最多的团称为**最大团**。“极大”只禁止继续扩张，不保证大小最大。贯穿图的极大团为 $\{1, 2, 3\}$ 、 $\{2, 3, 4\}$ ，二者恰好也都是最大团。团记录两两连接，高阶因子的作用域在原始图中成团，但团本身仍不决定函数值。

定义 9.8 树分解 有限无向图 $G = (V, E)$ 的树分解（tree decomposition）由一棵树 $\mathcal{T}$ 及各树顶点 t 对应的袋 $B_t \subseteq V$ 组成，满足：

1. 每个原图顶点至少出现在一个袋中；
2. 每条原图边的两个端点共同出现在某个袋中；
3. 对任意原图顶点 i ，全部满足 $i \in B_t$ 的树顶点在 $\mathcal{T}$ 中连通。

第三条称为**运行交集性质**（running intersection property）。

袋不是原图顶点，袋树的边也不是原图边。相邻袋之间只需交流交集上的信息。运行交集保证某变量的全部出现位置构成连通子树，可以沿它逐步核对一致性。图 9.5 显示，仅使袋树连通并不能替代这个条件。

满足运行交集



仅覆盖全部边



图 9.5 同一四顶点路径的两种袋连接。上行依次连接 $\{1, 2\}, \{2, 3\}, \{3, 4\}$ ，既覆盖边，又让每个变量的出现位置连通。下行同样覆盖全部边，却把含 2 的两个袋隔开，中间袋无法携带 2 的取值。因而下行不是树分解。框与框间连线分别表示袋和袋树边。

边覆盖只要求每一对相邻点在某袋中共同出现，为什么整个团也必须进入同一个袋？关键在于树上连通集合的一条特殊相交性质。

引理 9.9 树上连通子树的 Helly 性质 设 $\mathcal{T}_1, \dots, \mathcal{T}_m$ 是有限树 $\mathcal{T}$ 中的非空连通子树，且 $m \geq 1$ 。若任意两棵子树有公共顶点，则

$$\bigcap_{i=1}^m \mathcal{T}_i \neq \emptyset.$$

证明. 给 $\mathcal{T}$ 任选根，令 a_i 为 $\mathcal{T}_i$ 中离根最近的顶点。这个顶点唯一，且在根到任意 $x \in \mathcal{T}_i$ 的路径上：否则两个子树顶点的唯一路径会经过一个更靠近根的顶点，连通子树又必须包含整条路径，矛盾。取深度最大的 a_k 。

对任意 i ，由两两相交取 $x \in \mathcal{T}_i \cap \mathcal{T}_k$ 。 a_i, a_k 都在根到 x 的路径上，且 a_k 不比 a_i 浅，所以 a_k 位于 a_i 到 x 的路径上。 $\mathcal{T}_i$ 包含两端及其唯一路径，故含 a_k 。这对每个 i 成立， a_k 就是公共顶点。 ■

对原图顶点 v ，令 $\mathcal{T}_v = \{t : v \in B_t\}$ 。运行交集使它成为连通子树；对团 C ，边覆盖又使 $\{\mathcal{T}_v : v \in C\}$ 两两相交。由 Helly 性质，它们共有某个袋顶点 t ，也就是 $C \subseteq B_t$ 。因此，即使把计算拆到许多袋中，也必须有一个袋同时容纳大团中的全部变量；不能靠拆袋避免处理这些变量的联合取值。

局部块规模与树宽 树分解的宽度定义为 $\max_t |B_t| - 1$ ，图的树宽 (treewidth) 是所有树分解宽度的最小值。减一让一棵至少有一条边的树具有树宽 1：任选根，以根自身组成根袋，每个非根顶点与父顶点组成二元袋，再按原树的父子关系连接相应袋，即可覆盖全部边并满足运行交集；有边又使宽度不可能为零。单顶点图的树宽为 0。

贯穿图的两个袋

$$B_a = \{1, 2, 3\}, \quad B_b = \{2, 3, 4\}$$

连接成树，宽度为 2。另一方面，三角形必须完整进入某袋，使任意分解宽度至少为 2，故其树宽恰为 2。一般地，大小为 r 的团给出下界 $r - 1$ ；任一实际构造的分解给出上界。只报告一个启发式分解的宽度，还不能声称已经算出了最小树宽。

若每个变量最多有 q 个候选值，一个大小为 $k + 1$ 的袋需要至多 q^{k+1} 个条目来显式存储稠密局部表。因此小树宽控制的是同时索引的变量数，而不是自动保证任意任务都便宜。还须知道局部表能否有效访问、候选数是否有界、袋数是否适中。后文将证明树宽等于最优消元次序的最大剩余邻居数；此处只建立结构和状态规模，数值查询的正确性留到配置函数一节。

9.3.2 图的结构提取与计算简化

9.3.2.1 基于生成树的连接骨架提取

如果任务只要求保留全图连接，可以删去冗余边，得到覆盖全部顶点的树。连通无向图的这种子图称为生成树 (spanning tree)；非连通图则在每个分量中取一棵树，合起来称为生成森林。它们不是重新增加顶点或边，而是从原边集中抽取连接骨架。

BFS 或 DFS 记录的父边已经给出构造：从每个尚未访问顶点启动一次遍历，每次发现新顶点只保留它的父边。一个分量中的所有点都被发现，父边不成环，所以由定理 9.2 得到该分量的生成树。若原图有 n 个顶点、 c 个连通分量，生成森林恰有 $n - c$ 条边。

这种抽取保留的是每个原分量内仍有路径，而不是保留全部路径、环或分离关系。贯穿图可以保留边 $\{1, 2\}, \{2, 3\}, \{2, 4\}$ ，得到以 2 为中心的树。原图中 1 与 3 直接相邻，树中距离却变为两步；原图没有割点，树中 2 却成为割点。BFS 父树额外保留从所选起点出发的无权距离，但一般不保留所有顶点对距离。至于哪棵生成树的总成本最小，是第 9.4.3 节的优化问题，不能只凭任意遍历父树回答。

9.3.2.2 基于顶点消元的作用域简化

删边抽骨架可能丢掉约束，不能用于需要保持原查询的局部计算。另一种简化是把一个变量的影响收进剩余变量上的新表，然后不再显式保留该变量。所有含变量 z_i 的局部表一起处理以后，结果通常依赖于它的全部剩余邻居。因此图上须先把这些邻居两两连接，再删除 i 。这称为一次消元 (elimination)，新加的连接称为填充边 (fill edge)。它记录中间表可能的联合依赖，不是原问题新增了一个独立约束。

贯穿图采用

$$\pi_{\text{good}} = (1, 4, 2, 3)$$

时，先删 1 的剩余邻居 $\{2, 3\}$ 已经相邻，再删 4 时同样如此，全程无需补边。采用

$$\pi_{\text{bad}} = (2, 1, 3, 4)$$

时，第一步的剩余邻居 $\{1, 3, 4\}$ 尚未成团，必须补入 $\{1, 4\}$ 。原图相同，处理次序却改变了新表同时依赖的变量数。

记消元次序为 π ，在删除 v 前的当前填充图中，尚未删除的邻居为 $N_{\pi}^{+}(v)$ 。上标 + 在这里表示次序中的后继，不是有向图的出邻域。该次序的诱导宽度 (induced width) 为

$$k_{\pi} = \max_v |N_{\pi}^{+}(v)|.$$




图 9.6 两个初步消元产生不同接口。删去 z_1 后，新表索引 (z_2, z_3) ；删去 z_2 后，通常须索引 (z_1, z_3, z_4) ，黄虚线为填充边 $1-4$ 。二值稠密接口表分别有 4 和 8 项，虽然两张余图都只剩三个顶点。特殊函数可能还能分解；图给出的是通用作用域范围。

好、坏次序分别有宽度 2, 3。若变量最多有 q 个候选值，一次处理 $\{v\} \cup N_\pi^+(v)$ 的工作表至多有 $q^{k_\pi+1}$ 项，输出接口表则至多有 q^{k_π} 项。显式保存所有接口的空间通常含 $O(|V|q^{k_\pi})$ 项，逐步扫描工作表的时间通常含 $O(|V|q^{k_\pi+1})$ 项。显式展开一步联合表还需 $O(q^{k_\pi+1})$ 工作空间；原始因子存储、因子数量与局部访问成本另计。这些是有限稠密表的规模估计，尚未证明任何具体汇总规则能保持答案。

消元不仅给出成本上界，还能构造满足运行交集的袋。

定理 9.10 消元序产生树分解 给定有限无向图的完整消元次序 π ，每一步把剩余邻居补成团。则袋 $B_v = \{v\} \cup N_\pi^+(v)$ 可以连接成树分解，宽度不超过 k_π 。因此树宽不大于任一消元次序的诱导宽度。

证明. 为比较各步邻接，保留全部原顶点，并把过程中出现的所有填充边加入原图，记所得图为 $\mathcal{H}_\pi$ 。每个 $N_\pi^+(v)$ 在其中成团。该集合非空时，取其中最早消去的顶点 $p(v)$ ，把袋 B_v 连接到 $B_{p(v)}$ ；集合为空时令 B_v 为根袋。父指针始终指向次序更晚的顶点，且每个非根袋只有一个父袋，所以构成森林。每个顶点属于自己的袋；原边 $\{u, v\}$ 若 u 先删，则 $v \in N_\pi^+(u)$ ，该边由 B_u 覆盖。

固定原图顶点 z 。若 $z \in B_v$ 而 $v \neq z$ ，则 $z \in N_\pi^+(v)$ 。剩余邻居已成团，故若 $p(v) \neq z$ ， z 与 $p(v)$ 在后者删除前仍相邻，且 z 删得更晚，所以 $z \in B_{p(v)}$ 。沿父袋逐步向上，直到 B_z 之前，每个袋都含 z 。全部含 z 的袋因而连通，也都在同一棵树中。若有多棵树，可以任意添加根袋之间的连接使之成为一棵树；不同树不共享原顶点，所以空交集连接不破坏运行交集。

最后， $|B_v| - 1 = |N_\pi^+(v)| \leq k_\pi$ ，故所得宽度不超过 k_π 。 ■

上一定理把消元次序变成树分解。要证明两者的最小宽度相同，还需反向构造：从给定树分解得到一个不会超过其宽度的消元次序。困难在于消元会补边，后面顶点的邻居可能比原图中更多。设给定宽度为 k 的树分解，维持如下不变量：剩余袋始终是当前填充图的树分解，而不仅覆盖原图。先移除被相邻袋包含的冗余叶袋；若剩余不止一个袋，对叶袋 B_ℓ 及其父袋 B_p ，令 $X = B_\ell \setminus B_p$ 。不冗余保证 $X \neq \emptyset$ ；运行交集说明 X 中顶点只出现在此叶袋，再由边覆盖知其当前邻居也全部位于 B_ℓ 。

依次消去 X 中的顶点，填充边两端仍在 B_ℓ 中，继续由此袋覆盖；从袋中删去已消顶点也不会破坏其他顶点的运行交集。每个被删顶点至多有 $|B_\ell| - 1 \leq k$ 个剩余邻居。当 X 删空，叶袋只剩接口 $B_\ell \cap B_p$ ，可由父袋完整容纳，于是删除叶袋而保持不变量。反复执行到只剩根袋，再任意消去根袋顶点。这构造出诱导宽度不超过 k 的完整次序。结合前一定理，得到

$$\text{tw}(\mathcal{G}) = \min_{\pi} k_{\pi}.$$

最小度或最少填充等启发式给出实际次序及可计算上界，却不保证达到这个最小值。数值消元是否正确，将在定理 9.28 中按运算条件证明；结构宽度小与代数运算合法缺一不可。

9.3.2.3 弦图条件下的无填充分解

完美消元序与无填充条件 什么图至少存在一个不必补边的消元次序？阻碍出现在没有捷径的长环：环上某点最先被删时，它的两个环邻居仍在，却没有连接。

定义 9.11 弦与弦图 无向简单图中，长度至少为 4 的环上，连接两个非相邻环顶点的边称为弦 (chord)。每个这类环都有弦的图称为弦图 (chordal graph)。给图补边直到成为弦图，称为弦化 (chordal completion)。

树没有环，因而满足弦图定义；四环至少要增加一条对角线。“弦”取决于两端在环上是否相邻，不取决于图中画的是直线还是曲线。弦图的诱导子图仍是弦图，因为诱导子图中任何无弦环也会是原图中的无弦环。

定义 9.12 单纯顶点与完美消元序 邻居组成团的顶点称为单纯顶点 (simplicial vertex)。若依次删除顶点时，每个顶点在删除前的剩余图中都是单纯顶点，这个次序称为完美消元序 (perfect elimination ordering)。

空邻域和单顶点邻域也满足成团条件。完美消元序恰好让每步无需填充，但存在这样的次序还需证明每个剩余图都能找到一个单纯顶点。




图 9.7 四环补入弦 1-3 后, 顶点 2 的两个邻居已经相邻。删除 2 不需填充, 余图 $\{1, 3, 4\}$ 是团, 因此 $(2, 1, 3, 4)$ 是补弦图的完美消元序。补边改变了原图的路径与分离关系, 不能把右图当作左图所有查询的等价表示。

引理 9.13 弦图的单纯顶点 每个非空有限弦图都有单纯顶点; 若它不是完全图, 则有两个互不相邻的单纯顶点。

证明. 对顶点数归纳。完全图的每点都单纯。若图不连通, 在两个分量各用归纳假设取一个单纯顶点; 其全图邻域与分量内相同, 二者仍单纯且不相邻。

设图连通但不完全, 取不相邻的 a, b , 并取按包含关系极小的 $a-b$ 分隔集 S 。令删去 S 后含 a, b 的分量为 C_a, C_b 。每个 $s \in S$ 在这两个分量内都须有邻居: 恢复 s 而保留其他条件点的删除后, 极小性要求有一条经过 s 的 $a-b$ 路径, 它的两侧分别通到 C_a, C_b 。若 $x, y \in S$ 不相邻, 在 $C_a \cup \{x, y\}$ 和 $C_b \cup \{x, y\}$ 内分别取最短 $x-y$ 路径。合起来得到至少四条边的环。同侧没有弦, 否则可缩短路径; 跨分量没有边, x, y 也无边, 所以这是无弦环, 矛盾。因此 S 是团。

对 $C = C_a$ 或 C_b , 诱导图 $G[C \cup S]$ 顶点更少且仍为弦图。若它完全, 任取 C 中的顶点; 若不完全, 归纳假设给出两个不相邻的单纯顶点, 因 S 是团, 其中至少一个在 C 。所取顶点在原图中没有 $C \cup S$ 外的邻居, 故在原图中仍单纯。分别从 C_a, C_b 取得的两点不相邻, 归纳完成。 ■

定理 9.14 弦图与完美消元序 有限无向图是弦图, 当且仅当它具有完美消元序。

证明. 若图为弦图, 上述引理给出单纯顶点。删去它的诱导子图仍为弦图, 可以重复, 直到图空, 从而得到完美消元序。反之, 若有完美消元序但存在长度至少为四的无弦环, 取环上最早删除的顶点。它的两个环邻居尚未删除, 且彼此不相邻, 所以它当时不是单纯顶点, 与定义矛盾。 ■

对任意次序, 把全部填充边加入保留原顶点的图, 后继邻居就已成团; 该次序在完成图中成为完美消元序, 故完成图是弦图。这不意味着原图本

来就是弦图，也不意味着原分离关系在补边后不变。贯穿图本来是弦图，但 π_{bad} 仍产生填充；弦图保证存在好次序，不保证任意次序都好。即使没有填充，大团仍然造成大宽度。

极大团与团树构造 弦图可以直接用极大团作袋，得到团树 (clique tree)。剩下的问题是如何连接这些团，使重复变量的出现位置连通。若以极大团为节点、把两个团的交集大小当作边权，那么满足运行交集的连接树恰好是总权重最大的生成树。下面说明这个优化目标为何能保证共享变量沿接口连通。这里先证明结构判据；选择最大权树的具体算法在第 9.4.3 节建立。

定理 9.15 最大权生成树与团树 设 $\mathcal{H}$ 为非空有限弦图， $\mathcal{C}$ 为其全部极大团。在以 $\mathcal{C}$ 为节点的完全无向图上，令 $w(C, D) = |C \cap D|$ ，包括交集为空时的零权边。候选图的一棵生成树满足运行交集，当且仅当它的总交集权最大。

证明. 先证团树存在。取完美消元序 $v_1, \dots, v_n$ ，建立 $K_i = \{v_i\} \cup N_i^+$ 。后继邻域已成团；若非空，把 K_i 连接到后继中序号最小顶点的袋 K_j ，则 $N_i^+ \subseteq K_j$ 。序号严格增加使连接无环；同一变量沿父袋一直保留到自己的袋，故运行交集成立。这也是定理 9.10 在无填充次序下的构造。

任一团取最早被消去顶点，其余顶点都属于该点的后继邻域，所以整个团包含在某个 K_i 中。各 K_i 本身又是团，故极大团恰是这些袋中的极大者。对一个被更大袋包含的非极大袋，选含它的极大袋；运行交集使二者间路径上的每个袋都含该非极大袋。因此可以将它收缩到路径上的相邻超集袋，不破坏任何变量的连通出现。逐次收缩非极大袋并去除重复袋后，只剩极大团。非连通图所得各树可用零交集边连接，得到团树。

再证最大权刻画。令 k_v 为含原顶点 v 的极大团数， $e_v(\mathcal{T})$ 为候选树中两端都含 v 的边数。这些边在 k_v 个团节点上构成森林，所以 $e_v(\mathcal{T}) \leq k_v - 1$ ，等号当且仅当这些团连通。交换有限求和次序，

$$\sum_{\{C, D\} \in E_{\mathcal{T}}} |C \cap D| = \sum_{v \in V} e_v(\mathcal{T}) \leq \sum_{v \in V} (k_v - 1).$$

刚构造的团树逐顶点取等号，所以总上界可达。任一最大权树若有某点未取等号，总和便严格小于上界，矛盾。故它满足运行交集；反过来，任一运行交集树达到同一上界，因而最大权。 ■

贯穿图只有两个极大团，唯一树边权为 2，表示共享顶点 2, 3。四环的极大团却只是四条原边；若能连成团树，每个原顶点所属的两个边团必须直接连接，这四个必要连接又成环，不可能是树。所以最大权选择不能修

复非弦图没有团树的障碍。在给定弦图上连接团，与在所有弦化中寻找最小树宽是两层不同的优化；团树也只给出接口，不替我们指定接口表上的数值运算。

9.3.2.4 有向与无向分离的等价表示

祖先道德化每次重新构造查询图。现在问更强的问题：在同一顶点集上，能否用一张固定的 DAG 或无向图保留全部分离关系？我们要求分离关系集合 $\mathcal{J}$ 完全相同，也就是对每个条件集合都给出相同答案，而不只是某一次查询碰巧相同。

定理 9.16 无向图的完美有向图表示 对有限无向图 $\mathcal{U} = (V, E_{\mathcal{U}})$ ，存在同顶点集 DAG $\mathcal{D}$ ，满足 $\mathcal{J}(\mathcal{D}) = \mathcal{J}(\mathcal{U})$ ，当且仅当 $\mathcal{U}$ 是弦图。对其完美消元序 $v_1, \dots, v_n$ ，将每条边从较晚顶点指向较早顶点，即得满足等式的完美有向图。

证明. 先设有完美消元序。沿所定箭头移动，序号严格减小，故无有向环。 v_i 的父集恰为后继邻域 N_i^+ ，已成团，所以所得 DAG 完美。若无向图有避开 S 的 $A-B$ 路径，取最短的一条。若它在 DAG 中出现碰撞点，两侧父节点已经相邻，可直接绕过而缩短路径，矛盾。所以此路径没有碰撞点，又避开 S ，必为活跃路径。反之，活跃路径上属于 S 的点只能是碰撞点；用每个碰撞点两侧父节点间已有的边绕过这些点，得到避开 S 的无向行走，去重复后即即为无向路径。因此所有分离查询对应。

再证必要性。设同顶点集 DAG 与 $\mathcal{U}$ 的分离集合相同。由引理 9.4，它的骨架必为 $\mathcal{U}$ 。它不能含未被遮蔽的碰撞 $i \rightarrow k \leftarrow j$ ，即 i, j 不相邻：不妨令 j 不是 i 的后代，取 $\text{pa}(i)$ ，按该引理的证明就能 d-分离它们；共同子点 k 不在这个父集中。无向路径 $i - k - j$ 却避开该条件集，与全部查询相同矛盾。

若 $\mathcal{U}$ 有长度至少为四的无弦环，取环中在 DAG 拓扑序里最晚的顶点，其两个环邻居都指向它，而这两个邻居不相邻，恰好造成未被遮蔽的碰撞，矛盾。故 $\mathcal{U}$ 为弦图。 ■

定理 9.17 有向图的完美无向图表示 对有限 DAG $\mathcal{D}$ ，存在同顶点集无向图 $\mathcal{U}$ ，使 $\mathcal{J}(\mathcal{U}) = \mathcal{J}(\mathcal{D})$ ，当且仅当 $\mathcal{D}$ 是完美有向图。此时骨架为弦图，且可取 $\mathcal{U} = \text{skel}(\mathcal{D})$ 。

证明. 若 $\mathcal{D}$ 完美，取拓扑序 $t_1, \dots, t_n$ 。按逆序删除骨架顶点时，删除 t_i 前剩余邻居恰为其父集，已成团，所以逆拓扑序是骨架的完美消元序。骨架因此为弦图；沿此消元序由较晚向较早定向，正好恢复 $\mathcal{D}$ 。前一定理遂给出 $\mathcal{J}(\text{skel}(\mathcal{D})) = \mathcal{J}(\mathcal{D})$ 。

反之，若等价无向图存在，邻接判据使它必等于骨架。若有未被遮蔽碰撞 $i \rightarrow k \leftarrow j$ ，不妨令 j 不是 i 的后代，则 $\text{pa}(i)$ d-分离 i, j ，却不含作为 i 子点的 k 。骨架路径 $i - k - j$ 仍避开该父集，不能被它无向分隔，矛盾。因此没有未被遮蔽的碰撞，即每个父集都已成团，DAG 完美。 ■

碰撞结构 $1 \rightarrow 3 \leftarrow 2$ 最直接地说明限制：空条件集分离 1, 2，给定 3 却使其活跃；普通无向分离不可能随条件集增加而重新接通。补上父节点间的边会消除这个障碍，但已经改变了图的分离关系。上述定理判定的是等价图表示，不是任意分布的数值分解保证。图的接口与改写规则至此建立，接下来才增加路径长度、容量和配置代价等优化语义。

9.4 图上的约束选择与优化

同一张图可以要求选一条低成本路径，也可以要求让多条路线共同承载流量，或为每个顶点选择一个标签。它们的可行方案不同，最优性的依据也不同。路径问题规定起终点，流量问题规定容量，生成树问题要求连接全部顶点，匹配问题要求每个顶点最多参与一次配对。若为顶点分配标签或划分区域，则还需要局部成本或规模平衡要求。在这些目标确定以后，再比较精确证书与松弛所得的质量界。

9.4.1 端点约束下的路径选择

以下加权算法统一在有向图上表述；无向边可替换为两条同长度的反向弧。因此本小节的负环包括这一转换后由无向负边产生的两弧有向环。沿用边长 ℓ_e ，令 $\mathcal{P}_{s,v}$ 是从 s 到 v 的简单路径集合， $\mathcal{W}_{s,v}$ 是允许重复顶点和边的有限行走集合。两个目标分别是

$$d_{\text{path}}(s, v) = \min_{P \in \mathcal{P}_{s,v}} \ell(P), \quad d_{\text{walk}}(s, v) = \inf_{W \in \mathcal{W}_{s,v}} \ell(W).$$

空候选集的值约定为 $+\infty$ 。前面已看到，有限图可达时简单路径有最小代价，行走却可能靠反复经过负环使代价任意下降。对当前目标 v ，只有当负环既能从 s 到达、又能继续到达 v 时，才有 $d_{\text{walk}}(s, v) = -\infty$ 。若不存在这种负环，删去行走中的非负闭合段就得到不更长的简单路径，两个目标值相等。

标准单源最短路算法求的是 d_{walk} 。先假设不存在从 s 可达的负环，记真实距离为 $D(v)$ 。零步行走给出 $D(s) = 0$ ，其余路径按最后一条弧分类：

$$D(s) = 0, \quad D(v) = \min_{u \rightarrow v} \{D(u) + \ell_{u,v}\} \quad (v \neq s). \quad (9.4)$$

空前驱集合的最小值为 $+\infty$ ，并约定 $+\infty + c = +\infty$ 。这使不可达顶点也服从同一表达式。无权图的边数距离已由 BFS 分层精确求出；加权图则要利用无环性、反复松弛或非负边长。

Bellman 关系不是无条件唯一的求解规则。例如 $s \rightarrow a$ 长 5， $a \rightarrow b$ 和 $b \rightarrow a$ 都长 0，任意 $D(a) = D(b) \leq 5$ 都满足局部等式，实际距离却是 5。因此算法还必须规定从起点零值、其他点正无穷出发的更新过程，不能把循环固定点的任意解当成距离。

9.4.1.1 无环图下的最短路递推

DAG 的拓扑序让每条路径的前缀先于终点处理。初始化 $L(s) = 0$ ，其余 $L(v) = +\infty$ ，按拓扑序更新

$$L(v) \leftarrow \min \left\{ L(v), \min_{u \rightarrow v} (L(u) + \ell_{u,v}) \right\}.$$

处理 v 时，所有入邻居已经处理，且以后不再改变。对拓扑序归纳：每条到达 v 的非空路径以某条 $u \rightarrow v$ 结束，其前缀代价不小于已求得的 $L(u)$ ；反过来，每个有限候选值都由实际路径见证。故二者取最小恰得真实距离。不可达顶点的所有候选仍为正无穷。起点的零步候选也被保留，DAG 中不存在从起点绕回起点的非空行走。

拓扑排序与遍历入边共需 $O(|V| + |A|)$ 时间。边长可以为负，因为证明依赖的是无环次序，不依赖路径前缀比整条路径更短。这正是 DAG 递推与下一种贪心算法的条件差别。

9.4.1.2 一般图下的最短路松弛

有环时，前驱的距离可能在以后下降，一遍更新不够。令 $L^{(0)}(s) = 0$ ，其余 $L^{(0)}(v) = +\infty$ ，按轮更新

$$L^{(k)}(v) = \min \left\{ L^{(k-1)}(v), \min_{u \rightarrow v} (L^{(k-1)}(u) + \ell_{u,v}) \right\}.$$

这里一轮右侧都使用上一轮标签。不变量是： $L^{(k)}(v)$ 等于至多使用 k 条边到达 v 的最小行走代价。 $k = 0$ 时仅有零步行走；归纳时，一个候选要么已用至多 $k - 1$ 条边，要么由这样的前缀加最后一条弧构成，恰好覆盖全部至多 k 边的行走。

记 $n = |V|$ 。若目标 v 不受从 s 可达的负环影响，任意到达它的行走都可删去非负闭合段，所以就有一条至多含 $n - 1$ 条边的简单路径达到有限最短距离。因此 $n - 1$ 轮给出这类目标的正确距离；不可达点仍为正无穷。这就是 Bellman-Ford 算法的基础，逐轮扫描的代价为 $O(n|A|)$ 。实现可以在一轮中就地使用更新值；那会提前传播某些路径，但“恰为至多 k 条边”

的等式只属于上述同步版本。就地版本仍覆盖全部至多 k 边候选，且每个有限标签仍由行走见证，故同样的轮数上界适用。

负环的影响不能只标一个顶点。固定第 $n-1$ 轮标签，再检查所有满足

$$L^{(n-1)}(u) < +\infty, \quad L^{(n-1)}(u) + \ell_{u,v} < L^{(n-1)}(v)$$

的弧，将其终点 v 作为种子，然后沿有向边遍历其全部后继。同步版本中，种子有一条代价优于全部至多 $n-1$ 边行走的至多 n 边行走。它必含重复顶点，且不能只含非负环，否则删环就得到更短边数的同样好候选，与严格改善矛盾。因此某个可达负环能够到达种子，再能到达其所有后继。

还要证明这种检查能找全受负环影响的顶点。对任一从 s 可达的负环，环上顶点都已有一条从 s 出发的简单路径，所以第 $n-1$ 轮标签都已有限。若环上没有任何弧满足严格改善，则沿环把 $L(v) \leq L(u) + \ell_{u,v}$ 相加，会得到 $0 \leq \ell(\text{环}) < 0$ ，矛盾。故环上至少有一个种子，其后继遍历覆盖该环能到达的全部顶点。这些且仅这些目标的 d_{walk} 为 $-\infty$ 。一个负环若不能从 s 到达，就不影响单源查询；若不能继续到达指定目标，也不改变该目标的距离。因此应分别说明是否发现可达负环、哪些目标的行走代价可以任意降低，以及当前讨论的是行走还是简单路径。负环会使行走下确界为负无穷，但有限图中的简单路径最小值仍然存在。

9.4.1.3 非负边长下的最短路贪心

若边长全部非负，就能每次永久确定一个顶点。Dijkstra 算法初始化暂定距离 $D(s) = 0$ 、其余为正无穷，维护已确定集合 S 。每次选择 S 外暂定距离最小的 u ，将它加入 S ，再用 $D(u) + \ell_{u,v}$ 松弛其出邻居，改善时记录前驱³。

定理 9.18 Dijkstra 算法的贪心正确性 若全部边长非负，则顶点 u 被选入已确定集合时，暂定距离 $D(u)$ 等于从 s 到 u 的行走下确界，也等于简单路径最小值。

证明. 有限暂定标签都由已发现的实际路线产生，因而不会低于真实最短距离。起点首先确定为零。假设此前选入顶点均正确，考虑新选入的 u 。若有一条到 u 的路径 P 比其标签更短，沿 P 取第一个尚不属于 S 的顶点 y ，以及它的前驱 $x \in S$ 。处理 x 时已经得到正确距离，松弛保证

$$D(y) \leq D(x) + \ell_{x,y} \leq \ell(P \text{ 到 } y \text{ 的前缀}).$$

剩余边长非负，所以此前缀代价不超过 $\ell(P)$ 。选择规则又给出 $D(u) \leq D(y)$ ，于是 $D(u) \leq \ell(P)$ ，与假设的严格更短矛盾。若最小暂定值已为正无穷而

³T. H. Cormen, C. E. Leiserson, R. L. Rivest, C. Stein, *Introduction to Algorithms*, MIT Press, 2022, 4th ed.

尚有可达顶点，沿到它的路径同样可找到从 s 跨出的第一条边，其松弛会产生有限标签，仍矛盾。因此剩余点确实不可达。 ■

上述选择和松弛对应两种数据操作。优先队列 (priority queue) 按暂定距离这个“键”维护候选，支持取出并删除最小键，以及降低某个已有候选的键。二叉堆 (binary heap) 是它的一种实现：把候选排在按层填满、末层从左填入的二叉树中，每个父节点的键不大于子节点，因此根节点给出最小键。保存 n 个候选时树高为 $O(\log n)$ ；删除最小键或降低键后，沿一条树路径调整即可恢复次序。若同时记录每个顶点在堆中的位置，就能直接找到待降键项，两种操作均只需 $O(\log n)$ 时间。Dijkstra 至多取出 $|V|$ 次，并通过邻接表对每条弧尝试一次降键，因而在 $|V| \geq 2$ 时得到 $O((|V| + |A|) \log |V|)$ 的总代价。例如

$$\ell_{s,a} = 2, \quad \ell_{s,b} = 5, \quad \ell_{a,b} = 1, \quad \ell_{a,t} = 5, \quad \ell_{b,t} = 2.$$

算法先确定 a 的距离 2，把 b 从 5 改为 3；再确定 b ，把 t 从 7 改为 5，恢复路径 $s \rightarrow a \rightarrow b \rightarrow t$ 。非负性恰用于“前缀代价不超过全路径”。若只取三弧 $\ell_{s,a} = 2, \ell_{s,b} = 5, \ell_{b,a} = -4$ ，算法会先把 a 确定为 2，真实距离却是 $5 - 4 = 1$ 。这里没有负环，贪心仍失败；DAG 递推和 Bellman-Ford 则都可正确处理。

9.4.2 容量约束下的流量选择

路径只选一条路线，流量可以由多条路线共同输送。在有限有向网络中指定不同的源点 s 、汇点 t ，每条弧具有有限非负容量 $c_{i,j}$ 。流 (flow) 是满足容量限制和内部流守恒的弧数值：

$$0 \leq f_{i,j} \leq c_{i,j}, \quad \sum_{u: u \rightarrow v} f_{u,v} = \sum_{w: v \rightarrow w} f_{v,w} \quad (v \neq s, t).$$

流值 $|f|$ 是源点的净流出量，不是所有弧流量的总和。一个 s - t 割由 $s \in S, t \notin S$ 的顶点集确定，容量为

$$c(S, V \setminus S) = \sum_{\substack{i \in S \\ j \notin S}} c_{i,j}.$$

对 S 内守恒式求和，内部流量相消，跨割净流出等于 $|f|$ 。正向流出不超过容量，反向流入非负，所以任意流值不超过任意割容量。

定理 9.19 最大流最小割定理 在有限非负容量网络中，最大 s - t 流值等于最小 s - t 割容量。

证明. 零流可行; 容量约束将每条弧的流量限制在闭有界区间, 守恒等式又是闭条件, 所以有限维的可行流集合非空且紧. 流值连续, 因此最大流 f 存在. 为每条原弧 $i \rightarrow j$ 建立容量 $c_{i,j} - f_{i,j}$ 的正向残量弧, 以及容量 $f_{i,j}$ 的反向残量弧, 只在容量为正时允许通行. 残量弧需保留所属原弧的身份; 原网络若已有反向弧, 不把两种作用混为一个流变量.

若残量网络有 $s-t$ 路径 P , 令 $\delta > 0$ 为其最小残量容量. 沿正向残量弧令对应原流增加 δ , 沿反向残量弧令对应原流减少 δ . 瓶颈保证新流不超过容量也不为负, 路径内部每点的流入与流出变化抵消, 源点的净流出量却增加 δ , 与最大流的假设矛盾.

令 S 为残量网络中从 s 可达的全部顶点, 则 $t \notin S$. 从 S 指向补集的原弧必须已满, 否则可沿正向残量继续到达; 从补集指入 S 的原弧必须流量为零, 否则可沿其反向残量离开 S . 于是

$$|f| = \sum_{\substack{i \in S \\ j \notin S}} f_{i,j} - \sum_{\substack{i \notin S \\ j \in S}} f_{i,j} = \sum_{\substack{i \in S \\ j \notin S}} c_{i,j} = c(S, V \setminus S).$$

任意流不超过任意割, 而这里一个可行流与一个割同值, 所以两者分别最优. ■

残量网络记录方案如何调整, 不是额外的实际通道. 原弧 $a \rightarrow b$ 容量为 3、已发 2 时, 正向残量 1 允许追加, 反向残量 2 允许撤回; 撤回不要求原网络具有实际的 $b \rightarrow a$ 通道.

若全部容量为整数, 从零流开始, 每次选整数瓶颈增广, 所有流始终为整数. 每次流值至少增加 1, 而流值至多 $C_s = \sum_{j: s \rightarrow j} c_{s,j} < \infty$, 故至多 C_s 次增广便终止. 终止时无残量路径, 上述割证书证明所得流最优, 也就证明整数最优流存在. 这个次数依赖容量的数值, 未必是容量二进制位数的多项式. 对有理数或有限精度输入, 可用有明确有限步保证的最大流算法, 并把精确运算与位长成本计入复杂度; 例如每次按 BFS 选边数最少的残量增广路, 有不依赖容量数值的增广次数界. 任意实数容量下, 紧性仍保证最优流存在, 却不能据此保证任意增广选路有限终止, 更不能在没有有效数值表示时声称机器可精确求解.

取整数容量

$$c_{s,a} = 3, \quad c_{s,b} = 2, \quad c_{a,b} = 1, \quad c_{a,t} = 2, \quad c_{b,t} = 3.$$

依次沿 $s \rightarrow a \rightarrow t$ 、 $s \rightarrow b \rightarrow t$ 、 $s \rightarrow a \rightarrow b \rightarrow t$ 增广 2, 2, 1, 得到流值 5. 割 $S = \{s\}$ 的容量恰为 $3 + 2 = 5$, 任何流值都不可能超过这个割的容量, 所以当前流已经最优.




图 9.8 同值流与割构成最优性证书。左图标容量，右图标流量/容量；内部顶点均满足流守恒。黄虚线划出 $S = \{s\}$ ，跨出它的容量为 $3 + 2 = 5$ ，等于已实现流值。图中画的是原网络弧，未画残量反向弧。

9.4.3 全图连接下的生成树选择

生成树已能保留一个连通分量的连接。若每条无向边有建造成本 w_e ，最小生成树 (minimum spanning tree, MST) 还要求所选 $n - 1$ 条边的成本之和最小。它不要求树上的端点距离仍是原图最短路：三角形边长为 2, 2, 3 时，MST 选两条长 2 的边，总成本 4，却把原来由长 3 的直连边连接的两点距离增为 4。

对非平凡划分 $(S, V \setminus S)$ ，跨割成本最小的边称为轻边。成本可以为负，证明只比较相对大小。

引理 9.20 最小生成树的割性质 若边集 A 包含在某棵 MST 中，且割 $(S, V \setminus S)$ 不切断 A 的任何边，则跨割的一条轻边 e 可以与 A 共同包含在某棵 MST 中。

证明. 取包含 A 的 MST T 。若 $e \in T$ 即得结论。否则加入 e 形成唯一环；该环还须通过另一条跨割边 f ，才能回到原侧。轻边条件给出 $w_e \leq w_f$ 。删除 f 得到生成树 $T' = T + e - f$ ，成本不大于最优的 T ，所以仍最优。割没有切断 A 中的边，故 $f \notin A$ ，于是 T' 仍包含 A 及 e 。 ■

割性质给出一个逐步选边的办法。Kruskal 算法按成本从小到大扫描边，只接纳连接两个当前分量的边。对被接纳边的一端当前分量作割，已选边不会跨出该分量。若还存在成本更小的跨割边，它早已被扫描：当时两端若在不同分量，该边会被接纳；若已在同一分量，之后也不会分开。两种情形都使它的两端现在属于同一分量，与跨割矛盾。因此当前边是该割的轻边。割性质归纳保证每一步已选边都可扩充为 MST；连通性使最终得到生成树。Prim 算法则维护一个已连通顶点集，每次加入跨它与补集的轻边，同样满足割性质。Kruskal 的实现先排序，再用并查集 (disjoint-set union) 维护当前分量：find(v) 返回顶点所在组的代表，两个端点代表不同才接纳该边，随后用 union 合并两组。这个数据结构直接对应“不在已

连通分量内部加边”的要求。Prim 则复用前面的优先队列，对尚未加入的每个顶点保存连接当前已连通集的最便宜边；新顶点加入后，通过邻接表更新这些键。它的键是跨割单边成本，与 Dijkstra 记录从起点出发的累计路径距离不同。

多条边成本相同时，可能有多棵 MST，但这些树的最小总成本相同；负成本不破坏交换证明。非连通图应逐分量求最小生成森林，不能声称得到了全图生成树。第 9.3.2.3 节的团候选图需要最大总交集权，把成本改为交集权的相反数，或反向排序，就可用同一交换论证求最大权生成树。其运行交集保证来自团树定理，不来自贪心算法本身。

9.4.4 端点互斥下的匹配选择

设左右两组对象之间有候选配对，每个对象最多参与一次配对。把候选配对写成二部图 $\mathcal{G} = (U, W, E)$ 后，一个可行方案就是一组不共享端点的边，称为 **匹配** (matching)。不能直接再加入任何边的叫极大匹配；边数在所有匹配中最多的才叫最大匹配。局部无法添加，不表示通过替换已有边也无法改善。

为求最大基数匹配，建立源点到每个 $u \in U$ 的容量 1 弧，每条候选边改为容量 1 弧 $u \rightarrow w$ ，再由每个 $w \in W$ 连容量 1 弧到汇点。任一匹配的每条边沿 $s \rightarrow u \rightarrow w \rightarrow t$ 发送一单位，得到同值整数流。反过来，整数流的每条 $u \rightarrow w$ 取值为 0 或 1；源侧单位容量限制每个 u 至多选一次，汇侧单位容量同样限制每个 w 。因此流值为 k 当且仅当所选边构成大小 k 的匹配。整数容量保证存在整数最大流，所以此归约精确求出最大匹配，而非用分数边代替实际配对。

匹配的**增广路径** (augmenting path) 是两个尚未匹配端点之间的路径，其边交替为未匹配边和已匹配边，首尾都是未匹配边。沿路径翻转选择状态，内部顶点仍恰有一条匹配边，两个端点各新增一条，所以匹配大小增加 1。在上述网络里，这就是残量 s - t 路径：未匹配边正向走，已匹配边反向撤回。无增广路径时无残量路径，割证书遂证明最大性。

例如当前选择 $a-x, b-y$ ，虽然未匹配的 c 不能直接加入 $c-y$ ，却可走 $c-y-b-z$ ，撤去 $b-y$ ，加入 $c-y, b-z$ ，得到大小 3 的匹配。

一般非二部图含奇环，不能直接使用这套左右两组的流构造；加权匹配还把目标改成总权重，最大边数也不再自动意味着最大收益。图类别、可行约束与目标必须同时核对。

9.4.5 图结构约束下的顶点配置选择

现在不选边，而是为每个顶点赋值。若相邻顶点取值不同就要付出代价，同一套边差分可以表达二值边界，也可以表达实数值的平滑程度。本小节




图 9.9 沿交替路径重新安排匹配。两组顶点为 $U = \{a, b, c\}$ 、 $W = \{x, y, z\}$ 。蓝实线是已选边，左图红虚线是增广路径的未选边，灰线是其余候选边。翻转 $c - y - b - z$ 后保留 $a - x$ ，得到三条互不共享端点的边。线条表达候选配对，不表达因果方向。

先建立这种共同能量，再分别研究成对成本下的二值优化和带规模平衡的划分。

固定无向非负权图，非边权重为零，令 $\mathbf{W} = [w_{i,j}]$ 为对称权重矩阵。加权度（weighted degree）及其对角矩阵为

$$d_i^{(w)} = \sum_j w_{i,j}, \quad \mathbf{D}^{(w)} = \text{diag}(d_1^{(w)}, \dots, d_n^{(w)}).$$

加权度不同于普通度 $d_i = |N(i)|$ ；仅在每条结构边权均为 1 时二者相同。下列谱结论依赖正权支撑图 $\mathcal{G}_+ = (V, E_+)$ ，零权结构边不贡献差分⁴。

⁴ F. R. K. Chung, *Spectral Graph Theory*, American Mathematical Society, 1997, 1st ed.

定义 9.21 组合图拉普拉斯 有限无向非负权图的组合图拉普拉斯 (combinatorial graph Laplacian) 为

$$\mathbf{L} = \mathbf{D}^{(w)} - \mathbf{W}. \quad (9.5)$$

对顶点值 $\mathbf{f} \in \mathbb{R}^n$,

$$(\mathbf{L}\mathbf{f})_i = \sum_j w_{i,j}(f_i - f_j).$$

它汇总本点与邻居的差；相邻值已相等的边不再产生作用。用关联矩阵 $\mathbf{B}$ 和边权对角矩阵 $\mathbf{W}_E$ 也可写成 $\mathbf{L} = \mathbf{B}\mathbf{W}_E\mathbf{B}^\top$ 。逐列相乘可见，每条边给两端对角元各加 w_e ，给两个交叉位置各加 $-w_e$ ，合计正是 $\mathbf{D}^{(w)} - \mathbf{W}$ 。第 9.1.2 节已证明临时边方向不会改变此乘积。

定理 9.22 图拉普拉斯的 Dirichlet 能量与零空间 对有限无向非负权图，

$$\mathbf{f}^\top \mathbf{L}\mathbf{f} = \frac{1}{2} \sum_{i,j} w_{i,j}(f_i - f_j)^2 \geq 0. \quad (9.6)$$

因而 $\mathbf{L}$ 对称半正定。其零空间由各正权支撑连通分量的指示向量张成，维数等于这些分量的个数。

证明. 由权重对称性和行和定义,

$$\begin{aligned}\mathbf{f}^\top \mathbf{L} \mathbf{f} &= \sum_i d_i^{(w)} f_i^2 - \sum_{i,j} w_{i,j} f_i f_j \\ &= \frac{1}{2} \sum_{i,j} w_{i,j} (f_i^2 + f_j^2 - 2f_i f_j).\end{aligned}$$

这给出能量等式及半正定性。系数 $1/2$ 是因为有序对 (i, j) 把每条无向边计了两次；若按 $\{i, j\} \in E$ 求和，就不再需要此系数。

若 $\mathbf{L} \mathbf{f} = \mathbf{0}$ ，则二次型为零。各项非负，使每条正权边满足 $f_i = f_j$ 。沿支撑图路径传递，同一支撑连通分量中的值必相等。反之，每个支撑分量内取任意常数时，正权边端点差为零，零权边不贡献，所以 $\mathbf{L} \mathbf{f} = \mathbf{0}$ 。不同分量的指示向量线性无关，又能组合出全部这类分段常数，遂得维数结论。 ■

二次型称为图的 Dirichlet 能量：它测量沿边的平方变化，并非顶点值的平方和。负边权可能破坏非负性；真正有向图又有不同的拉普拉斯定义，不能直接继承这里的对称谱论。

即使两个顶点与各自邻居的差取同一个非零值，连接总权重较大的顶点也会得到幅度较大的累计差分。若希望按各点的连接总权重调整这种尺度，就需要对拉普拉斯作归一化。

定义 9.23 对称归一化拉普拉斯 对称归一化拉普拉斯 (symmetric normalized graph Laplacian) 为

$$\mathbf{L}_{\text{sym}} = (\mathbf{D}^{(w)})^{-1/2} \mathbf{L} (\mathbf{D}^{(w)})^{-1/2}. \quad (9.7)$$

对 $d_i^{(w)} = 0$ 的支撑孤立点，约定逆平方根条目为 0，因而该点对应的行列为零。

令 $\mathbf{g} = (\mathbf{D}^{(w)})^{-1/2} \mathbf{f}$ ，则 $\mathbf{f}^\top \mathbf{L}_{\text{sym}} \mathbf{f} = \mathbf{g}^\top \mathbf{L} \mathbf{g} \geq 0$ 。这里把零特征值对应的方向简称为零模。在全部顶点度数为正的支撑连通分量中，零特征向量为 $(\mathbf{D}^{(w)})^{1/2} \mathbf{1}$ 在该分量的限制；每个零度点的坐标单位向量也属于零空间。这里的零度点可能仍有零权结构边，“孤立”仅针对正权支撑。

对正度顶点 i ，系数 $w_{i,j}/d_i^{(w)}$ 非负且对 j 求和为 1，所以 $\sum_j w_{i,j} f_j / d_i^{(w)}$ 是邻居数值的加权平均。把本点数值减去这个平均，得到通常称为随机游走拉普拉斯的矩阵作用： $\mathbf{L}_{\text{rw}} = (\mathbf{D}^{(w)})^{-1} \mathbf{L}$ ，零度逆条目也可约定为零。这

个名称还允许把归一化系数解释为下一步选择邻居的概率；随机游走与 Markov 链的完整概率定义将在第 10 章展开，这里只使用有限权重的归一化。全为正度时，

$$\mathbf{L}_{\text{sym}} = (\mathbf{D}^{(w)})^{1/2} \mathbf{L}_{\text{rw}} (\mathbf{D}^{(w)})^{-1/2}.$$

因此两者相似； $\mathbf{L}_{\text{rw}}$ 通常不是欧氏对称矩阵，但由 $\mathbf{D}^{(w)} \mathbf{L}_{\text{rw}} = \mathbf{L} = \mathbf{L}^\top$ ，它在内积 $\langle \mathbf{x}, \mathbf{y} \rangle_{\mathbf{D}} = \mathbf{x}^\top \mathbf{D}^{(w)} \mathbf{y}$ 下自伴。有零度点时该式不再是全空间上的正定内积，须限制到正度顶点再作这一判断。

算子 内积与每个连通分量的零模

$\mathbf{L}$ 欧氏内积；分量内顶点值为常量，零模为分量指示向量

$\mathbf{L}_{\text{sym}}$ 欧氏内积，信号坐标按度缩放；零模为分量上的 $\sqrt{d_i^{(w)}}$ 向量

$\mathbf{L}_{\text{rw}}$ 度加权内积下自伴；分量内顶点值为常量

表 9.1 同一非负权图的三种拉普拉斯几何。表中假设全部顶点为正度；零度点按正文约定另行处理。改变坐标与改变内积是两种不同操作，不能把三种算子的特征向量直接互换。

9.4.5.1 成对成本下的二值标签优化

令顶点标签 $z_i \in \{0, 1\}$ 。每个顶点选择标签时有自己的代价；相邻两个顶点的标签组合也可能产生代价。我们分别用一元成本和成对成本记录这两项。回到第 2.2.1.2 节的离散目标，

$$\mathcal{E}(\mathbf{z}) = \sum_i D_i(z_i) + \sum_{\{i,j\} \in E} \theta_{i,j}(z_i, z_j). \quad (9.8)$$

这里 $\mathcal{E}$ 是能量函数， E 仍是边集。二值时 $(z_i - z_j)^2 = |z_i - z_j|$ ：同标签时为零，异标签时为一。这恰好与边是否跨割对应，所以非负边差成本可以写成割容量。但任意四项成对成本未必有这种表示。

若

$$\theta_{i,j}(0, 0) + \theta_{i,j}(1, 1) \leq \theta_{i,j}(0, 1) + \theta_{i,j}(1, 0), \quad (9.9)$$

称该成对项为次模 (submodular)。它比较的是两项之和，不要求每个同标签配置都比每个异标签配置便宜。

定理 9.24 二值次模成对能量的割表示 若式 (9.8) 的全部一元项和成对项均为有限实数，且每个成对项次模，则存在非负容量的 s - t 网络，使每个二值配置的割容量等于其能量加同一个常数。因而最小割给出全局最优配置。

证明. 固定一条边, 简记 $\theta_{a,b} = \theta_{i,j}(a,b)$, 令

$$w_{i,j} = \frac{\theta_{0,1} + \theta_{1,0} - \theta_{0,0} - \theta_{1,1}}{2}, \quad (9.10)$$

$$\alpha_i = \theta_{1,0} - \theta_{0,0} - w_{i,j}, \quad \alpha_j = \theta_{0,1} - \theta_{0,0} - w_{i,j}. \quad (9.11)$$

次模性恰保证 $w_{i,j} \geq 0$, 且

$$\theta_{i,j}(z_i, z_j) = \theta_{0,0} + \alpha_i z_i + \alpha_j z_j + w_{i,j} |z_i - z_j|. \quad (9.12)$$

逐项核对四种配置:

$$\begin{aligned} (0,0) : \quad & \theta_{0,0} = \theta_{0,0}, \\ (1,0) : \quad & \theta_{0,0} + \alpha_i + w_{i,j} = \theta_{1,0}, \\ (0,1) : \quad & \theta_{0,0} + \alpha_j + w_{i,j} = \theta_{0,1}, \\ (1,1) : \quad & \theta_{0,0} + \alpha_i + \alpha_j = \theta_{1,1}. \end{aligned}$$

最后一式利用 $2w_{i,j} = \theta_{0,1} + \theta_{1,0} - \theta_{0,0} - \theta_{1,1}$. 对所有边重复, 将常数累加、线性项并入一元函数, 得到

$$\mathcal{E}(\mathbf{z}) = C + \sum_i D'_i(z_i) + \sum_{\{i,j\} \in E} w_{i,j} |z_i - z_j|.$$

置 $m_i = \min\{D'_i(0), D'_i(1)\}$, $\tilde{D}_i(a) = D'_i(a) - m_i \geq 0$, 并令 $C' = C + \sum_i m_i$. 这个平移只改常数, 不改最优配置。

源侧规定为标签 0, 汇侧为标签 1. 加入容量 $\tilde{D}_i(1)$ 的弧 $s \rightarrow i$, 容量 $\tilde{D}_i(0)$ 的弧 $i \rightarrow t$. 若 i 在源侧, 只有后者跨割, 支付 $\tilde{D}_i(0)$; 若在汇侧, 只有前者跨割, 支付 $\tilde{D}_i(1)$. 每条成对边另建两条容量均为 $w_{i,j}$ 的反向弧。同侧时都不计费; 异侧时只有从源侧指向汇侧的一条计费, 所以无论标签是 (0,1) 还是 (1,0), 都只支付一次 $w_{i,j}$.

于是割容量为 $\mathcal{E}(\mathbf{z}) - C'$. 每个配置唯一决定变量顶点的两侧归属, 每个割也唯一给出配置, 故二者的最小值及最优配置相互对应。 ■

有限实值保证表示及最优解存在; 实际精确计算还需要容量有效编码。对有理数或机器有限精度数, 可调用最大流算法。更一般的可图割表示能量条件见 Kolmogorov 和 Zabih⁵。

例如

$$D_1(0) = 0, \quad D_1(1) = 2, \quad D_2(0) = 2, \quad D_2(1) = 0, \quad w_{1,2} = 1.$$

四个配置 (0,0), (0,1), (1,0), (1,1) 的能量分别为 2, 1, 5, 2。最小割把 1 放源侧、2 放汇侧, 只付中间边界成本 1, 恢复 (0,1)。

⁵ V. Kolmogorov, R. Zabih, *What Energy Functions Can Be Minimized via Graph Cuts?* In IEEE Transactions on Pattern Analysis and Machine Intelligence, 2004, vol. 26, no. 2, pp. 147–159




图 9.10 两变量能量的割表示，零容量弧省略。割把 $s, 1$ 与 $2, t$ 分开，因而标签为 $z_1 = 0, z_2 = 1$ 。两个容量为 1 的反向弧中，仅源侧到汇侧的黄弧 $1 \rightarrow 2$ 计费，成本不是 2。终端弧 $s \rightarrow 1$ 的容量 $2 = D_1(1)$ 只在顶点 1 进入汇侧时支付。

若次模不等式失败，上述 $w_{i,j} < 0$ ，便不能用非负容量按此构造表示。多标签、高阶项或一般非次模目标也不能自动化成一次最小割；辅助顶点、分层网络或连续二值子问题都需要各自的等价性或近似保证。

9.4.5.2 规模平衡下的图划分优化

若只想切断较弱的连接，普通最小割往往会孤立一个连接稀少的顶点。允许空侧时甚至直接得到零割。要得到两个有意义的区域，需要在边界成本之外计入规模平衡；按顶点数平衡与按连接体积平衡会导出不同的特征问题。

先由谱定理取 L 的标准正交特征向量 $\mathbf{u}_1, \dots, \mathbf{u}_n$,

$$0 = \lambda_1 \leq \lambda_2 \leq \dots \leq \lambda_n.$$

当 $n \geq 2$ 且正权支撑连通时， $\mathbf{u}_1 = \mathbf{1}/\sqrt{n}$ 、 $\lambda_2 > 0$ 。为了比较不同幅度的信号，先将边差能量除以信号的平方范数，得到 Rayleigh 商

$$\frac{\mathbf{f}^\top L \mathbf{f}}{\mathbf{f}^\top \mathbf{f}}$$

衡量；排除常量方向后，最小值为 λ_2 ，对应的第二特征向量称为费德勒向量 (Fiedler vector)。强连接两端取近似值可以降低能量，而两个内部紧密、相互较弱的区域可以各自近似常量。阈值化这种实数方向才会得到离散划分，并非特征向量本身就是分组。

对 $S \subset V$ ，令 $s_i = \mathbb{I}\{i \in S\}$ ，则

$$\mathbf{s}^\top L \mathbf{s} = \sum_{\substack{i \in S \\ j \notin S}} w_{i,j} = \text{cut}(S, V \setminus S). \quad (9.13)$$

因为同侧差为零，异侧平方差为一，每条跨边被计一次。记 $\bar{S} = V \setminus S$ ， $a = |S| > 0, b = |\bar{S}| > 0, a + b = n$ 。比率割 (RatioCut) 为

$$\text{RatioCut}(S, \bar{S}) = \text{cut}(S, \bar{S}) \left(\frac{1}{a} + \frac{1}{b} \right). \quad (9.14)$$

在边界成本相同时, 较小的一侧会使此目标更大。要把这个离散目标变成可用谱方法处理的二次型, 需要给两个区域分别指定一个常数, 并使全图的数值和为零。构造两水平向量

$$f_i = \begin{cases} \sqrt{b/a}, & i \in S, \\ -\sqrt{a/b}, & i \in \bar{S}. \end{cases} \quad (9.15)$$

直接核对

$$\mathbf{1}^\top \mathbf{f} = a\sqrt{b/a} - b\sqrt{a/b} = 0, \quad \mathbf{f}^\top \mathbf{f} = a(b/a) + b(a/b) = n.$$

跨边的端点差为 $\sqrt{b/a} + \sqrt{a/b} = n/\sqrt{ab}$, 所以

$$\begin{aligned} \mathbf{f}^\top \mathbf{L} \mathbf{f} &= \frac{n^2}{ab} \text{cut}(S, \bar{S}) \\ &= n \text{RatioCut}(S, \bar{S}). \end{aligned} \quad (9.16)$$

离散比率割等价于在这些两水平向量中最小化 Rayleigh 商。去掉两水平限制而保留平衡、尺度, 得到谱松弛

$$\min_{\substack{\mathbf{f} \in \mathbb{R}^n \\ \mathbf{f}^\top \mathbf{1} = 0, \mathbf{f}^\top \mathbf{f} = n}} \frac{1}{n} \mathbf{f}^\top \mathbf{L} \mathbf{f}. \quad (9.17)$$

取 $\mathbf{u}_1 = \mathbf{1}/\sqrt{n}$, 其余基与它正交。可行向量展开为 $\mathbf{f} = \sum_{k=2}^n \alpha_k \mathbf{u}_k$, 因而

$$\frac{\mathbf{f}^\top \mathbf{L} \mathbf{f}}{\mathbf{f}^\top \mathbf{f}} = \frac{\sum_{k=2}^n \lambda_k \alpha_k^2}{\sum_{k=2}^n \alpha_k^2} \geq \lambda_2.$$

$\sqrt{n} \mathbf{u}_2$ 达到等号, 所以 λ_2 是离散最优值的下界, 不保证阈值化后的离散割达到此值。支撑不连通时可按分量取相反常量, 同样得到下界 0, 但第二零模不再有唯一的划分方向。

归一化割 (Normalized Cut, NCut) 改用体积

$$\text{vol}(S) = \sum_{i \in S} d_i^{(w)}.$$

内部边在两端各计一次, 跨边在本侧端点计一次; 顶点数相同的集合未必有相同体积。先假设全部顶点为正度, 记 $p = \text{vol}(S) > 0$ 、 $q = \text{vol}(\bar{S}) > 0$, $\text{vol}(V) = p + q$, 定义

$$\text{NCut}(S, \bar{S}) = \text{cut}(S, \bar{S}) \left(\frac{1}{p} + \frac{1}{q} \right). \quad (9.18)$$

令

$$y_i = \begin{cases} \sqrt{q/p}, & i \in S, \\ -\sqrt{p/q}, & i \in \bar{S}. \end{cases}$$

此时

$$\mathbf{y}^\top \mathbf{D}^{(w)} \mathbf{1} = p\sqrt{q/p} - q\sqrt{p/q} = 0, \quad \mathbf{y}^\top \mathbf{D}^{(w)} \mathbf{y} = p + q.$$

跨边差为 $(p+q)/\sqrt{pq}$, 于是

$$\mathbf{y}^\top \mathbf{L} \mathbf{y} = \frac{(p+q)^2}{pq} \text{cut}(S, \bar{S}) = \text{vol}(V) \text{NCut}(S, \bar{S}).$$

这次保留的是度加权的平衡与尺度。放宽两水平限制后, 得到度加权 Rayleigh 问题

$$\min_{\substack{\mathbf{y} \neq \mathbf{0} \\ \mathbf{y}^\top \mathbf{D}^{(w)} \mathbf{1} = 0}} \frac{\mathbf{y}^\top \mathbf{L} \mathbf{y}}{\mathbf{y}^\top \mathbf{D}^{(w)} \mathbf{y}}. \quad (9.19)$$

固定分母为 $\text{vol}(V)$, 拉格朗日函数为

$$\mathcal{J}(\mathbf{y}, \lambda, \mu) = \mathbf{y}^\top \mathbf{L} \mathbf{y} - \lambda(\mathbf{y}^\top \mathbf{D}^{(w)} \mathbf{y} - \text{vol}(V)) - \mu \mathbf{y}^\top \mathbf{D}^{(w)} \mathbf{1}.$$

驻点满足

$$2\mathbf{L} \mathbf{y} - 2\lambda \mathbf{D}^{(w)} \mathbf{y} - \mu \mathbf{D}^{(w)} \mathbf{1} = \mathbf{0}.$$

左乘 $\mathbf{1}^\top$, 利用 $\mathbf{1}^\top \mathbf{L} = \mathbf{0}^\top$ 及平衡约束, 得 $-\mu \text{vol}(V) = 0$, 故 $\mu = 0$ 。于是

$$\mathbf{L} \mathbf{y} = \lambda \mathbf{D}^{(w)} \mathbf{y}, \quad \mathbf{y}^\top \mathbf{D}^{(w)} \mathbf{1} = 0. \quad (9.20)$$

令 $\mathbf{x} = (\mathbf{D}^{(w)})^{1/2} \mathbf{y}$, 等价地最小化

$$\min_{\substack{\mathbf{x} \neq \mathbf{0} \\ \mathbf{x}^\top (\mathbf{D}^{(w)})^{1/2} \mathbf{1} = 0}} \frac{\mathbf{x}^\top \mathbf{L}_{\text{sym}} \mathbf{x}}{\mathbf{x}^\top \mathbf{x}}.$$

正交谱展开说明, 全局最小值是 $\mathbf{L}_{\text{sym}}$ 的第二特征值; 应取其第二特征向量, 再变回 $\mathbf{y}$, 而不只是求一个任意驻点。一般不规则图上, 它不是组合拉普拉斯的费德勒向量。正度正则图满足 $\mathbf{D}^{(w)} = d\mathbf{I}$, 两种方向才必然重合。有零度点时体积可能为零, 必须先单独处理这些点, 不能直接除以 p, q 。

为了手算比较两种平衡要求, 这里暂把贯穿图换成四顶点单位权路径 $1-2-3-4$:

$$\mathbf{L} = \begin{bmatrix} 1 & -1 & 0 & 0 \\ -1 & 2 & -1 & 0 \\ 0 & -1 & 2 & -1 \\ 0 & 0 & -1 & 1 \end{bmatrix}, \quad \mathbf{D}^{(w)} = \text{diag}(1, 2, 2, 1).$$

对 $S = \{1, 2\}$, 只有中间边跨割, $a = b = 2$,

$$\text{RatioCut}(S, \bar{S}) = 1, \quad \mathbf{f} = (1, 1, -1, -1)^\top, \quad \frac{\mathbf{f}^\top \mathbf{L} \mathbf{f}}{\mathbf{f}^\top \mathbf{f}} = \frac{4}{4} = 1.$$

该路径的第二特征值与方向为

$$\lambda_2 = 2 - \sqrt{2} \approx 0.586, \quad \mathbf{u}_2 \propto (1 + \sqrt{2}, 1, -1, -1 - \sqrt{2})^\top.$$

零阈值恢复中间分割。枚举非平凡二分得到离散最优 RatioCut 为 1, 并不等于松弛下界 $2 - \sqrt{2}$ 。

同一分割两侧体积均为 3, 所以

$$\text{NCut}(S, \bar{S}) = \frac{2}{3}, \quad \frac{\mathbf{f}^\top \mathbf{L} \mathbf{f}}{\mathbf{f}^\top \mathbf{D}^{(w)} \mathbf{f}} = \frac{4}{6} = \frac{2}{3}.$$

广义特征问题则给出

$$\lambda_{2,\text{sym}} = \frac{1}{2}, \quad \mathbf{y}_2 \propto (1, 1/2, -1/2, -1)^\top, \quad \mathbf{L} \mathbf{y}_2 = \frac{1}{2} \mathbf{D}^{(w)} \mathbf{y}_2.$$

零阈值仍恢复离散 NCut 最优的中间分割, 其值为 $2/3$ 。两个问题在此例恰好同分组, 但特征方程、向量幅度和下界不同。




图 9.11 单位权四顶点路径的两种谱方向。蓝实线为组合拉普拉斯第二特征向量, 红虚线为度加权广义特征向量, 点形也作区分。显示时均按欧氏范数 2 缩放, 不替代 NCut 的度加权范数。横轴为四个离散顶点, 连线仅引导阅读; 竖虚线标出零阈值分割, 两种方向虽同号分组, 相对幅度并不相同。

将连续方向按阈值变成离散分组后, 必须回到原来的 RatioCut 或 NCut 目标核验质量。特征向量的方向稳定性还依赖相邻特征值间隔: 与其他特征值的间隔很小时, 小扰动可能使方向明显旋转; 重特征值时应考察对应子空间, 只有它与其他谱充分分离时才能谈相应稳定性, 不能把任意单个基向量当成固有划分。

9.4.6 离散选择的近似与质量验证

前面的谱划分已经展示了通用做法：扩大可行域获得下界，再恢复原约束下的方案获得上界。仅把 $z_i \in \{0, 1\}$ 改成 $z_i \in [0, 1]$ 还没有完整指定松弛，必须说明连续域上的目标怎样定义。记原可行集为 $\mathcal{Z}$ ，选 $\tilde{\mathcal{Z}} \supseteq \mathcal{Z}$ 及延拓 $\tilde{\mathcal{E}}$ ，要求

$$\tilde{\mathcal{E}}(\mathbf{z}) = \mathcal{E}(\mathbf{z}) \quad (\mathbf{z} \in \mathcal{Z}).$$

则

$$L_{\text{relax}} = \inf_{\mathbf{z} \in \tilde{\mathcal{Z}}} \tilde{\mathcal{E}}(\mathbf{z}) \leq \mathcal{E}^* = \min_{\mathbf{z} \in \mathcal{Z}} \mathcal{E}(\mathbf{z}).$$

不同延拓即使在离散点上一致，也可能得到不同下界。若松弛最优值达到，且存在一个松弛最优解属于原可行集，它同时就是离散全局最优解；若松弛解不满足原来的离散约束，就还需要取整、局部搜索或分支定界。

恢复出可行配置 $\hat{\mathbf{z}}$ 以后，令 $U = \mathcal{E}(\hat{\mathbf{z}})$ ，任何有效下界 $L \leq \mathcal{E}^*$ 都给出

$$0 \leq U - \mathcal{E}^* \leq U - L.$$

$U - L$ 是次优差距的上界，不是实际误差；仅在下界紧时二者相等。数值求解器当前的连续可行目标通常是松弛最优值的上界，不能未经对偶证书或误差控制就把它称为原问题下界。逐坐标按 1/2 阈值取整也可能破坏总数、连通等全局约束；必须先检查恢复方案可行，才有上界 U 。

确定性取整需要逐实例的质量证明。采用随机取整时，还须利用后续第10章的概率工具说明抽样规则、平均误差与修复可行性的代价；本节的上下界证书则逐个检查所得到的方案。非负且 $\mathcal{E}^* > 0$ 时， $U \leq \alpha \mathcal{E}^*$ 表达乘法近似比；目标可能为负或最优值为零时，加法误差 $U - \mathcal{E}^* \leq \varepsilon$ 更合适。运行快、连续目标下降与离散方案已最优是不同结论。

9.5 图上的函数与传播

沿边传播之前，先要明确传播的数值表示什么。给每个顶点一个数，与给每种完整配置一个数，是两种不同的函数。前者是 $f: V \rightarrow \mathbb{R}$ ，四顶点图只需四个值；后者是 $F: \mathcal{Z}_1 \times \cdots \times \mathcal{Z}_4 \rightarrow \mathcal{S}$ ，四个二值变量已有 16 种配置。对前者汇总邻居，会改变各个顶点的信号值；对后者汇总变量，是把某些变量的所有取值相加或取最优，得到只保留其他变量的表，或者一个全局最优值。二者都能沿图局部计算，却不能据此互换含义。

9.5.1 顶点函数的变换与传播

顶点数值可以表达温度、得分或某个观测通道；顶点标记则可以表达类别或局部结构类型。数值允许线性叠加，离散标记未必有加法，因此分别使

用谱变换和邻域细化。重编号只是坐标改变，两种运算都需要检查是否随顶点同步重排。

9.5.1.1 数值信号的谱变换与局部传播

假设在图的每个顶点放置一个传感器，记录该位置的温度。全部温度构成一个图信号 (graph signal)：给每个顶点一个数的函数，固定编号后写成 $\mathbf{f} \in \mathbb{R}^n$ 。规则序列可以统一向前平移一步，一般图却没有唯一的全局“下一个顶点”。要区分温度在相邻位置变化缓慢的部分与变化剧烈的部分，可以使用第 9.4.5 节的组合拉普拉斯，用沿边变化的能量确定适合本图的坐标，而不预设规则时间轴上的傅里叶公式。

谱定理给出

$$\mathbf{L} = \mathbf{U} \mathbf{\Lambda} \mathbf{U}^\top, \quad \mathbf{U}^\top \mathbf{U} = \mathbf{I}, \quad \mathbf{\Lambda} = \text{diag}(\lambda_1, \dots, \lambda_n).$$

其中 $0 = \lambda_1 \leq \dots \leq \lambda_n$ 。

定义 9.25 图傅里叶变换 选定 $\mathbf{L}$ 的一组实标准正交特征向量作为 $\mathbf{U}$ 的列，图信号的图傅里叶变换 (graph Fourier transform) 及逆变换为

$$\hat{\mathbf{f}}_{\mathcal{G}} = \mathbf{U}^\top \mathbf{f}, \quad \mathbf{f} = \mathbf{U} \hat{\mathbf{f}}_{\mathcal{G}}. \quad (9.21)$$

正交性使变换不丢信息，并有

$$\|\mathbf{f}\|_2^2 = \sum_{k=1}^n |\hat{f}_{\mathcal{G},k}|^2, \quad \mathbf{f}^\top \mathbf{L} \mathbf{f} = \sum_{k=1}^n \lambda_k |\hat{f}_{\mathcal{G},k}|^2.$$

对范数为一的特征向量，其边差能量正好等于对应特征值。因此小特征值对应沿边变化较小的模式，大特征值对应沿边变化较大的模式，这就是把 λ_k 称为图频率尺度的根据。若有重特征值，对应空间内可旋转正交基，单个坐标随之改变，该子空间上的投影及系数平方和却不变。图频率先对应特征空间，不总是一个唯一的特征向量；即使简单特征值的实特征向量也有正负号自由度。

单位权简单环提供与规则序列相接的例子。取 $N \geq 3$ ，顶点局部编号 $r = 0, \dots, N-1$ ，每点连到模 N 的左右邻居。这里的模态指标 $k = 0, \dots, N-1$ 按复指数编号，不按前面的特征值大小排序。直接计算

$$(\mathbf{L}\mathbf{f})[r] = 2f[r] - f[(r-1) \bmod N] - f[(r+1) \bmod N].$$

令 $u_k[r] = N^{-1/2}e^{2\pi ikr/N}$, 则

$$\begin{aligned} (\mathbf{L}u_k)[r] &= (2 - e^{-2\pi ik/N} - e^{2\pi ik/N})u_k[r] \\ &= \left(2 - 2\cos \frac{2\pi k}{N}\right)u_k[r]. \end{aligned}$$

不同 k 的内积为有限几何和: $\frac{1}{N} \sum_{r=0}^{N-1} e^{2\pi i(k-\ell)r/N}$ 在 $k = \ell$ 时为 1, 否则为 0. 故这些模式组成复酉基, 坐标变换用 $\mathbf{U}^* \mathbf{f}$, 逆变换用 $\mathbf{U}$, 不能把实情形的转置直接用于复基。这些复指数模式与前章定义 8.5 中的 DFT 使用同一组振荡函数; 这里以 $N^{-1/2}$ 归一化基向量, 所以图谱系数等于相应 DFT 系数除以 $\sqrt{N}$ 。直接代入环图算子并检查正交性, 说明同一组模式为何既适合循环平移, 也适合环图能量。 $N = 2$ 时简单图的左右邻居重合, 不能继续把该单边图写成度为 2 的上述环算子。

环图的 k 和 $N - k$ 具有相同特征值, 因而图能量并不区分两种复振荡方向。一般图的模式还依赖连接、边权和归一化选择; 两个不同图上的第 k 个系数没有天然相同的物理频率。跨图比较须依赖共同图构造、谱区间或子空间语义, 不能仅按坐标序号对齐。

谱坐标建立以后, 可以按标量响应 g 放大或缩小不同模态:

$$g(\mathbf{L}) = \mathbf{U}g(\mathbf{\Lambda})\mathbf{U}^\top, \quad \mathbf{y} = g(\mathbf{L})\mathbf{f}, \quad \hat{y}_{g,k} = g(\lambda_k)\hat{f}_{g,k}.$$

相同特征值必须使用相同标量响应, 所以 $g(\mathbf{L})$ 不依赖重特征空间内的任意基选择。若对同一特征值的不同基向量随意赋不同系数, 得到的就不是这个标量矩阵函数。

直接求整组特征向量可能很昂贵。若把响应限定为 K 次多项式, 就可以只用局部矩阵乘法计算滤波:

$$g(\mathbf{L}) = \sum_{r=0}^K \alpha_r \mathbf{L}^r, \quad (9.22)$$

则滤波写成

$$\mathbf{y} = \sum_{r=0}^K \alpha_r \mathbf{L}^r \mathbf{f}. \quad (9.23)$$

一次乘 $\mathbf{L}$ 只使用本点和一跳邻居的值。归纳地, 若 $(\mathbf{L}^r)_{i,j} \neq 0$, 矩阵乘积中必须存在至多 r 步的支撑图行走从 i 到 j , 对角因子允许停留; 因此图距离大于 K 时滤波矩阵条目为零。“至多 K 跳”是依赖范围上界, 不保证范围内每点的系数非零, 因为权重和多项式系数可能相消。给定稀疏图及多项式系数, 反复乘矩阵即可计算, 无需显式对角化; 每步成本为 $O(|V| + |E_+|)$ 。

三顶点路径的例子同时检验数值和范围：

$$\mathbf{L} = \begin{bmatrix} 1 & -1 & 0 \\ -1 & 2 & -1 \\ 0 & -1 & 1 \end{bmatrix}, \quad \mathbf{f} = (1, 0, 0)^\top, \quad g(\lambda) = 1 - \lambda/3.$$

于是

$$\mathbf{H}\mathbf{f} = (\mathbf{I} - \mathbf{L}/3)\mathbf{f} = (2/3, 1/3, 0)^\top.$$

首点的数值只到一跳邻居。该图特征值为 0, 1, 3，响应为 1, 2/3, 0，所以同一操作在谱坐标中消除了最高频模式。再作用一次，

$$\mathbf{H}^2\mathbf{f} = (\mathbf{I} - 2\mathbf{L}/3 + \mathbf{L}^2/9)\mathbf{f} = (5/9, 1/3, 1/9)^\top,$$

第三点才收到非零值，符合二次多项式的两跳范围。




图 9.12 三顶点路径上的一次与二次局部滤波。顶点下方为精确值，白色表示零值，浅蓝表示此前已非零的顶点，浅红表示本步新到达的顶点；初始非零点也用浅蓝标出。颜色不编码连续色标。图的边均为单位权无向边，没有时间箭头；从上行到下行表示反复作用 $\mathbf{H} = \mathbf{I} - \mathbf{L}/3$ 。两步结果的算子是二次多项式，能达到两跳邻居。

这种谱滤波有时也称图卷积，但一般没有规则网格上那种唯一的核平移。改变图或改用归一化拉普拉斯，同一个 g 会产生不同空间作用。局部多项式只是本图算子的函数，不自动继承普通平移卷积的全部性质。

还要检查编号是否影响结果。顶点级输出应随重编号同步重排, 称为等变; 整图级输出应保持相同, 称为不变, 完整定义见定义 7.10 和定义 7.9. 对第 9.1.3 节的置换矩阵 P ,

$$\begin{aligned} W' &= PWP^\top, & D^{(w)'} &= PD^{(w)}P^\top, \\ L' &= PLP^\top. \end{aligned} \quad (9.24)$$

若 $f' = Pf$, 则 $L'f' = PLf$. 更一般地, 由 $P^\top P = I$ 相邻消去,

$$g(L')f' = \sum_{r=0}^K \alpha_r (PLP^\top)^r Pf = Pg(L)f.$$

故多项式滤波等变; 若再对全部顶点求和, 重编号只会改变求和次序, 便得到不随编号改变的整图表示。不变性只排除任意编号的影响, 不保证不同非同构图一定得到不同结果。

有限次滤波每次最多增加有限跳数; 连续时间扩散则把局部差分累计成矩阵指数。若每点按邻居与自身的差调整, $f'_i(t) = \sum_j w_{i,j}(f_j(t) - f_i(t))$, 就得到

$$\frac{df(t)}{dt} = -Lf(t), \quad f(0) = f_0. \quad (9.25)$$

第 6 章的矩阵指数给出

$$f(t) = e^{-tL}f_0 = \sum_{k=1}^n e^{-t\lambda_k} \langle u_k, f_0 \rangle u_k.$$

各坐标独立按 $e^{-t\lambda_k}$ 衰减, 零模保持, 大特征值模式衰减更快。对任一支撑连通分量 C , 常量单位向量为 $\mathbf{1}_C/\sqrt{|C|}$, 其投影在每点的值为 $|C|^{-1} \sum_{i \in C} f_{0,i}$. 其余正特征值项趋于零, 所以每个分量分别趋于自己的初始平均; 支撑连通时才是全图同一平均。

守恒和耗散也可不经对角化验证。由 $\mathbf{1}^\top L = \mathbf{0}^\top$,

$$\frac{d}{dt} \mathbf{1}^\top f(t) = -\mathbf{1}^\top Lf(t) = 0.$$

平方范数与 Dirichlet 能量不能混称为同一个能量:

$$\frac{d}{dt} \frac{1}{2} \|f(t)\|_2^2 = f(t)^\top f'(t) = -f(t)^\top Lf(t) \leq 0.$$

边差能量的导数则为

$$\begin{aligned} \frac{d}{dt} [f(t)^\top Lf(t)] &= f'(t)^\top Lf(t) + f(t)^\top Lf'(t) \\ &= -2f(t)^\top L^2 f(t) = -2\|Lf(t)\|_2^2 \leq 0. \end{aligned}$$

对称性保证两项相同。前一个等式说明，平方范数一半对时间的导数等于当前边差能量的相反数；后一个等式说明，边差能量自身对时间的导数等于 $\|\mathbf{L}\mathbf{f}(t)\|_2^2$ 的负两倍。

贯穿图取单位边权、 $\mathbf{f}_0 = (1, 0, 0, 0)^\top$ ，其谱为 $0, 2, 4, 4$ 。不同模态的保留比例为 $1, e^{-2t}, e^{-4t}$ ，重特征值 4 的两个方向同速衰减。图连通且总和为 1，所以极限为每点 $1/4$ ，不是全部数值归零。




图 9.13 贯穿四顶点图的解析式扩散。左图比较 $\mathbf{f}(0) = (1, 0, 0, 0)^\top$ 与 $\mathbf{f}(1) = e^{-\mathbf{L}}\mathbf{f}(0)$ ，灰虚线是最终均值 $1/4$ ；右图绘制特征值 $0, 2, 4$ 的保留比例，4 的重数为 2。柱和曲线直接由该图的拉普拉斯计算，不表示实验均值或误差条。

指数一般不是固定低阶多项式，因此不能把有限次滤波的固定跳数截断套到它上面。扩散使总边差能量不增，却不保证每条边两端的差都单调缩小。例如单位权路径 $1-2-3$ 从 $\mathbf{f}(0) = (1, 1, 0)^\top$ 出发时， $\mathbf{f}'(0) = -\mathbf{L}\mathbf{f}(0) = (0, -1, 1)^\top$ 。边 $1-2$ 的初始差为零，差的导数却为 1，因此短时间内两端会从相等变为不等；此时总边差能量的导数仍为 -4 。整体耗散与逐边单调是两个不同的要求。扩散也不保证保留预测所需的类别边界，时间过长会抹去同一支撑分量内的全部非恒定差异。

图 Dirichlet 能量还与第 7 章的连续能量

$$\int_{\mathcal{M}} \|\text{grad } f\|_g^2 dV_g$$

形成离散与连续的对应：前者比较采样点之间的有限差分，后者累计无穷小方向的变化。但形式相似不构成收敛定理。若图来自点云，采样密度、邻域半径或核带宽、权重缩放、归一化及边界条件共同决定可能的极限。邻域太大可能把欧氏距离很近、沿流形却相距很远的两段连起来，太小则可能使图断连；未校正的不均匀采样可能导出带密度漂移的算子，而不是仅由 Riemann 体积确定的 Laplace–Beltrami 算子。离散谱结论相对于已选图精确成立，连续近似和任务语义仍各需额外条件。

9.5.1.2 离散标记的邻域细化

数值滤波考察信号变化，结构比较则常需知道各点周围有哪些类型的邻居。只记录出现过哪些类型会丢掉次数；按编号排列又依赖任意顺序。多重集合（multiset）保留种类与次数、忽略排列： $\{a, a, b\}$ 与 $\{a, b\}$ 不同。

定义 9.26 一维邻域标记细化 一维 Weisfeiler–Leman 细化（1-dimensional Weisfeiler–Leman refinement, 1-WL）从初始标记 $c_i^{(0)}$ 出发，同步更新

$$c_i^{(t+1)} = \text{HASH} \left(c_i^{(t)}, \left\{ \left\{ c_j^{(t)} : j \in N(i) \right\} \right\} \right), \quad (9.26)$$

其中 HASH 对不同输入对给出不同新标记。

这里要求不同输入得到不同编码，作为数学上的理想约定。实际有限哈希函数可能把不同输入映到同一值，不能直接宣称它满足这个约定。比较两图时必须共享初始标记规则和编码对应，例如在两图的不交并上统一编码，不能各自随意命名后比较字面值。同构只重排顶点及其邻居，所以每轮标记同步重排，各标记出现次数不变。上述版本仅用无向邻域；有向或带边属性的细化需要相应扩充输入，不能无声丢掉方向和属性。

令 $\mathcal{P}^{(t)}$ 为相同标记构成的分区。更新包含自身旧标记，所以旧标记不同的两点下一轮仍不同； $\mathcal{P}^{(t+1)}$ 只能细分，不能合并。每次严格细分至少增加一个非空块，而 n 点最多有 n 块，因此严格细分至多 $n-1$ 次。若某轮分区未变，同一块中的顶点已有相同的各旧块邻居计数，给这些块统一换新标记不会改变计数相等性，下一轮也不能再拆分，归纳可知以后一直稳定。这里“稳定”是相同标记组成的分组不再细分，标记的符号名称仍可以继续更新。

分组稳定以后，两个非同构图仍可能得到完全相同的标记计数。所有顶点初始同标记时，六环 C_6 与两个不相连三角形都让每点看到两个同标记邻居，归纳地每轮仍同标记，两图各有六个此类顶点。1-WL 无法区分它们，尽管前者连通、后者不连通。

给每个顶点附任意唯一编号不是无条件补救：若重编号后重新按编号赋特征，输出会依赖命名；若把额外属性随置换同步移动，可以保持等变，但问题已变成带属性图的比较。具体图网络的共享更新、聚合和读出能否达到或超过某种细化的区分能力，还须在模型章节依据函数族证明。输出随重编号同步变化，只说明运算不依赖任意命名；它不能保证区分所有不同结构，也不能保证模型对新图预测准确。




图 9.14 同样的邻居标记计数可以来自不同全局结构。两张六顶点图初始同标记, 每轮每点仍见到两个同标记邻居, 故 1-WL 计数无法区分一条六环与两个三角形。这不表示连通性难计算, 而是说明该细化遗漏了这一差异。浅黄只表示共同标记, 不加入唯一编号, 以保持无标记图的比较设定。

9.5.2 配置函数的汇总与查询

现在每个顶点 i 代表变量 z_i , 取值于非空有限集合 $\mathcal{Z}_i$; 贯穿例取 $\mathcal{Z}_i = \{0, 1\}$ 。配置函数 $F(\mathbf{z})$ 评价全部变量的一次完整赋值。图记录哪些变量同时进入局部函数, 查询则另行规定要输出总权重、最优值, 还是保留部分变量的函数表。只有明确输出以后, “消去变量” 才有确定含义。

9.5.2.1 配置查询的目标与半环运算

先不谈分解, 直接看两变量表

		$y = 0$	$y = 1$
$g(x, y) =$	$x = 0$	1	3
	$x = 1$	2	4

若数字是非负权重, 总权重与最佳权重分别为

$$\sum_{x,y} g(x, y) = 10, \quad \max_{x,y} g(x, y) = 4.$$

最佳权重的见证为 $(1, 1)$ 。若同一数字解释为成本, 最低成本为 1, 见证变为 $(0, 0)$ 。关系图相同, 甚至表也相同, 仍不能替读者决定查询。

若输出要保留 y , 求和消去 x 得到 $m(y) = \sum_x g(x, y)$, 即 $m(0) = 3, m(1) = 7$ 。这是一张表, 再汇总 y 才得标量 10。将每格权重除以 10, 得到给各对 (x, y) 分配份额的联合概率表; 各格非负, 全部份额相加为 1。把具有同一 y 的份额相加, 得到只记录 y 的边缘概率, 所以这里 $y = 0, 1$ 的概率分别是 $3/10, 7/10$ 。这一步只需对有限表求和; 一般概率分布将在第 10 章定义。若改为最大化, 得到 $m(0) = 2, m(1) = 4$, 记录每个 y 的最佳权重, 不再是边缘概率。消元是汇总内部变量的贡献, 不是删除它的约束。

为某个固定配置组合局部项，与跨不同配置汇总结果，是两种操作。普通权重用乘法组合、加法汇总；成本用加法组合、最小值汇总。分别记为 $\otimes$ 和 $\oplus$ ，核心规则是：不依赖被汇总变量的项可移到汇总外。

定义 9.27 交换半环 本章使用的交换半环 (semiring) 记为

$$(S, \oplus, \otimes, e_{\oplus}, e_{\otimes}),$$

包含一个集合、两种运算及其单位元。两种运算分别结合且交换，单位元分别为 $e_{\oplus}$ 、 $e_{\otimes}$ ，并满足

$$a \otimes (b \oplus c) = (a \otimes b) \oplus (a \otimes c), \quad a \otimes e_{\oplus} = e_{\oplus}.$$

空汇总取 $e_{\oplus}$ ，空组合取 $e_{\otimes}$ 。

半环不要求加法逆元或乘法逆元；这里的局部算法不需减法和除法。几个具体实例为

用途	S	$\oplus$	$\otimes$	$(e_{\oplus}, e_{\otimes})$
总权重	$\mathbb{R}_{\geq 0}$	+	$\times$	$(0, 1)$
最大权重	$\mathbb{R}_{\geq 0}$	max	$\times$	$(0, 1)$
最小成本	$\mathbb{R} \cup \{+\infty\}$	min	+	$(+\infty, 0)$
是否可行	$\{\text{false}, \text{true}\}$	$\vee$	$\wedge$	$(\text{false}, \text{true})$

最大积中的 0 既是最大值运算的单位元，也是乘法吸收元。最小加法约定 $+\infty + c = +\infty$ ，用正无穷表达不可行。对数域还可用 $(\mathbb{R} \cup \{-\infty\}, \max, +, -\infty, 0)$ ，约定 $-\infty + c = -\infty$ 。这些选择改变答案，不能只当成实现细节。

再引入局部因子。在贯穿图上，只有一元与成对因子时，可写为

$$F(\mathbf{z}) = \bigotimes_{i \in V} \phi_i(z_i) \otimes \bigotimes_{\{i,j\} \in E} \phi_{i,j}(z_i, z_j). \quad (9.27)$$

因子是局部函数，作用域是它依赖的变量集合。若要表达原三元子句，仍须保留 $\phi_{2,3,4}(z_2, z_3, z_4)$ ；上述成对公式不是从三个两两关系恢复三元约束的等价式。一般可写 $F(\mathbf{z}) = \bigotimes_a \phi_a(\mathbf{z}_{S_a})$ ，其中 $S_a \subseteq V$ 为任意有限作用域。改变作用域会改变分解和计算成本，即使某些数值条目恰好相同。

例如和积下要保留 z_4 ，查询为

$$Q(z_4) = \sum_{z_1, z_2, z_3} F(\mathbf{z}), \quad Z = \sum_{z_4} Q(z_4).$$

只有在 F 是非负权重且 $0 < Z < \infty$ 时, F/Z 才为每个完整配置分配非负且总和为 1 的概率, $Q(z_4)/Z$ 才是只保留 z_4 的边缘概率。若总权重为零, 就不能作这种归一化。若改问最低成本, 目标为 $\min_{\mathbf{z}} [\sum_i c_i(z_i) + \sum_{\{i,j\} \in E} c_{i,j}(z_i, z_j)]$, 就须同时更换组合和汇总。图本身不自动添加概率、因果或时间语义。

9.5.2.2 基于变量消元的查询与恢复

第 9.3.2.2 节已说明消元如何改变作用域, 现在证明它如何保持数值查询。每次收集全部含 z_i 的当前因子 $\mathcal{F}_i$, 合并其作用域并去掉 i , 记剩余接口为 R_i , 生成

$$\psi_i(\mathbf{z}_{R_i}) = \bigoplus_{z_i \in \mathcal{Z}_i} \bigotimes_{f \in \mathcal{F}_i} f.$$

删去这些旧因子, 以 ψ_i 替换; 其余因子保持不动。这不是丢掉 z_i 的影响, 而是对每个剩余接口值预先算出它的全部贡献。完整消元的目标, 在贯穿成对例中为

$$Z = \bigoplus_{\mathbf{z} \in \mathcal{Z}_1 \times \dots \times \mathcal{Z}_4} \left[\bigotimes_i \phi_i(z_i) \otimes \bigotimes_{\{i,j\} \in E} \phi_{i,j}(z_i, z_j) \right]. \quad (9.28)$$

定理 9.28 半环变量消除的正确性 对有限取值变量和交换半环, 按任意完整次序对有限个局部因子执行上述消元, 所得标量等于直接枚举的全局汇总。特别地, 式 (9.27) 得到式 (9.28)。若保留一组输出变量, 在其余变量消去后停止, 所得表逐个输出配置等于原查询。

证明. 维持更强的不变量: 对每个尚未消去变量的固定配置, 当前因子的半环组合等于原函数对已消去变量的汇总。初始没有已消变量, 不变量即为原局部分解。

设下一变量是 z_i , 把当前因子分成含它的 $\mathcal{F}_i$ 和不含它的 $\mathcal{F}_{-i}$ 。固定其他变量, 有限性和分配律给出

$$\bigoplus_{z_i} \left[\left(\bigotimes_{f \in \mathcal{F}_{-i}} f \right) \otimes \left(\bigotimes_{f \in \mathcal{F}_i} f \right) \right] = \left(\bigotimes_{f \in \mathcal{F}_{-i}} f \right) \otimes \left(\bigoplus_{z_i} \bigotimes_{f \in \mathcal{F}_i} f \right).$$

右侧最后一项就是新因子 ψ_i 。结合律与交换律允许把对 z_i 的汇总接在此前已消变量的有限汇总之后, 因而新的当前组合等于原函数对全部已消变

量的汇总，不变量保持。若再对剩余变量汇总，上式也表明每一步的全局值不变：

$$\begin{aligned} & \bigoplus_{z_{-i}} \bigoplus_{z_i} \left[\left(\bigotimes_{f \in \mathcal{F}_{-i}} f \right) \otimes \left(\bigotimes_{f \in \mathcal{F}_i} f \right) \right] \\ &= \bigoplus_{z_{-i}} \left[\left(\bigotimes_{f \in \mathcal{F}_{-i}} f \right) \otimes \psi_i \right]. \end{aligned}$$

归纳到所有变量消去，只剩直接枚举的标量。若输出变量不消去，同一逐配置不变量即给出所需函数表。 ■

正确性允许任意次序，中间表成本却不相同。贯穿图先消去 1, 4 只需保留接口 {2, 3}；先消去 2 则形成对 {1, 3, 4} 的表，并出现填充边 {1, 4}。结构部分给出的 q^{k+1} 工作表界因此控制实际消元，而不改变查询定义。

和积得到的是未归一化权重；保留输出变量后仍需除以同一总权重，并检查总权重严格为正。最大积则得到

$$M = \max_{\mathbf{z}} \prod_i \phi_i(z_i) \prod_{\{i,j\} \in E} \phi_{i,j}(z_i, z_j).$$

只存最大值不能恢复最优配置。每次对接口配置保存一个达到最大值的 z_i ，最后从未次选择开始，按消元逆序用已知接口值查回选择，即能恢复一个全局见证。每一步都保存条件最优选择，反向代入使该步达到原先记录的局部最优值，归纳便得到全局值 M 。并列时须声明固定平局规则、返回任意一个或枚举全部；枚举全部的输出规模可能很大。

最小加法同理求得

$$C^* = \min_{\mathbf{z}} \left[\sum_i c_i(z_i) + \sum_{\{i,j\} \in E} c_{i,j}(z_i, z_j) \right],$$

并保存条件最小选择回溯；若最优值为 $+\infty$ ，就应报告没有有限成本可行配置。严格正权重可用负对数把最大积转成最小加法，因为乘积变为和，负对数反转大小次序。零权重约定映为 $+\infty$ ，负权重则没有直接的实对数解释；若用普通对数，得到的是最大加法而非最小加法。

同一种有限汇总可换序，不同汇总通常不行。取

$$h(x, y) = \begin{array}{c|cc} & y=0 & y=1 \\ \hline x=0 & 4 & 0 \\ x=1 & 0 & 4 \end{array}.$$

要求先固定同一个 x 、再累计全部 y ，得到

$$\max_x \sum_y h(x, y) = 4. \quad (9.29)$$

允许每个 y 分别选择最佳 x ，则为

$$\sum_y \max_x h(x, y) = 8. \quad (9.30)$$

区别是是否允许选择随 y 而改变。一般对有限实值表，

$$\max_x \sum_y h(x, y) \leq \sum_y \max_x h(x, y),$$

因为对任意固定 x ，每个 $h(x, y) \leq \max_{x'} h(x', y)$ ，相加再最大化仍保序。若某个共同 x 在所有 y 上同时最大，两种运算都在每个 y 处取得同一最大项，所以取等号；反过来，若取等号，取左侧一个最优 x ，逐项非负差的总和为零，故每项都为零，也就必须有这样一个共同最优选择。

混合求和与最大化因此限制合法消元次序，最小可用宽度可能超过普通树宽。按配置概率求和得到边缘概率、直接寻找权重最大的完整配置，以及先求和再对保留变量最大化，是不同的查询，不能混用目标或消元次序。把有限和改成连续积分，还须回用定理 3.41：在 σ 有限乘积测度下，非负可测函数可由 Tonelli 换序，带符号函数通常需要 Fubini 的绝对可积条件。把求和号改成积分号不自动保证存在性、换序或有限表算法仍适用。

9.5.2.3 基于树形消息的局部查询

消元把内部变量的影响存入接口表。若多个子问题通过一棵树的接口相连，就可以计算好一侧的表，再把它交给另一侧复用；这种沿接口传递的函数表称为消息。在贯穿图的一元与成对情形中，先消去 z_1 所得表为

$$m_{1 \rightarrow \{2,3\}}(z_2, z_3) = \bigoplus_{z_1 \in \mathcal{Z}_1} \phi_1(z_1) \otimes \phi_{1,2}(z_1, z_2) \otimes \phi_{1,3}(z_1, z_3). \quad (9.31)$$

同样计算 z_4 一侧的 $m_{4 \rightarrow \{2,3\}}$ ，再在接口上组合两条消息与 $\phi_2, \phi_3, \phi_{2,3}$ ，最后汇总 z_2, z_3 。若还有三元因子 $\phi_{2,3,4}$ ，应把它完整纳入 4 侧表。每种接口配置的局部结果只算一次。

合法性的直接原因是分配律，而不只是图形看起来分成两侧。对不依赖 z_1 的项 $c(z_2, z_3)$ ，

$$\bigoplus_{z_1} (c(z_2, z_3) \otimes g(z_1, z_2, z_3)) = c(z_2, z_3) \otimes \bigoplus_{z_1} g(z_1, z_2, z_3).$$

图确定哪些项与内部变量无关, 半环公理允许移出汇总, 接口表则保存可复用的子问题答案。

先在一棵树上严格定义消息。顶点放一元因子, 边放成对因子; 删去 $\{u, v\}$, 记 u 侧连通分量为 $T_{u|v}$ 。消息不是只汇总顶点 u , 而是汇总整棵 u 侧子树:

$$m_{u \rightarrow v}(z_v) = \bigoplus_{z_{T_{u|v}}} \left[\bigotimes_{i \in T_{u|v}} \phi_i(z_i) \otimes \bigotimes_{\substack{\{i,j\} \in E \\ i,j \in T_{u|v}}} \phi_{i,j}(z_i, z_j) \otimes \phi_{u,v}(z_u, z_v) \right]. \quad (9.32)$$

唯一保留的自变量为接口值 z_v , 跨接口边项也必须计入。

定理 9.29 树消息递推 对有限取值变量、有限树及交换半环, 上述消息满足

$$m_{u \rightarrow v}(z_v) = \bigoplus_{z_u} \left[\phi_u(z_u) \otimes \phi_{u,v}(z_u, z_v) \otimes \bigotimes_{r \in N(u) \setminus \{v\}} m_{r \rightarrow u}(z_u) \right]. \quad (9.33)$$

证明. 对子树 $T_{u|v}$ 大小归纳。若 u 为叶顶点, 没有入消息, 空组合为单位元, 递推就是对 $\phi_u \otimes \phi_{u,v}$ 汇总 z_u , 与定义相同。若还有邻居 $r \neq v$, 删除 u 后, 各 $T_{r|u}$ 互不重叠, 彼此无边; 否则会破坏树的唯一路径性质。归纳假设将每个这样的子树连同通往 u 的边概括为 $m_{r \rightarrow u}(z_u)$ 。结合律与交换律允许按子树分组, 分配律把仅依赖 z_u, z_v 的项移到各子树汇总之外, 再汇总 z_u , 便得到递推式。每个顶点因子、内部边因子和接口边因子都被计入恰好一次。 ■

任取根 r , 从叶到根汇集消息以后,

$$Z = \bigoplus_{z_r} \left[\phi_r(z_r) \otimes \bigotimes_{u \in N(r)} m_{u \rightarrow r}(z_r) \right].$$

不汇总 z_r 就得到根的查询表; 再把消息从根发回各枝, 可在每个顶点组合全部入消息, 得到相应未归一化边缘表或条件最优表。和积的归一化与最优查询的选择回溯仍遵循上一小节, 消息本身不替代这些步骤。

一般图可先用树分解或团树形成袋。每个因子作用域在原始图中成团，团入袋性质保证能把因子完整分配给一个包含它的袋，并且只分配一次。记袋 B 的因子组合为 Φ_B ，相邻袋 B, C 的接口为 $S_{B,C} = B \cap C$ ，递推为

$$m_{B \rightarrow C}(z_{S_{B,C}}) = \bigoplus_{z_B \setminus S_{B,C}} \left[\Phi_B(z_B) \otimes \bigotimes_{D \in N_{\mathcal{T}}(B) \setminus \{C\}} m_{D \rightarrow B}(z_{D \cap B}) \right].$$

运行交集保证同一变量的全部出现位置在袋树中连通。因此，若某变量同时出现在删去树边后的两侧，它必属于该边接口；若出现在两个相邻子树，也必经过当前袋。因此固定袋配置就为每个入消息指定一致的接口值；不同入消息中、当前袋以外的内部变量不会重叠，相关局部因子也不会跨越两侧，可以沿子树归纳。运行交集失效时，同一变量可能在两枝被独立取不同值，这正是无效树分解会破坏查询的原因。

贯穿图中叶袋 $\{1, 2, 3\}$ 向袋 $\{2, 3, 4\}$ 发送关于 z_2, z_3 的表，后者组合自己的一元或高阶因子完成查询。若分解宽度为 k 、每变量至多 q 个状态，枚举袋配置至多用 q^{k+1} 项，接口表通常更小；还须计入原始因子读取、袋数和每次半环运算成本。给定袋数为多项式量级的正确分解、固定 k, q 、可有效计算的局部表及运算，整体才有关于顶点数的多项式保证。寻找最优树分解本身是另一问题，宽度随顶点数增长时也没有这个固定参数保证。

在原始有环图上直接反复发送树形公式的消息，某个局部项可能经不同路线返回，造成重复计数；子树互不重叠的证明已经失效。这种循环消息可作为近似方法研究，但是否收敛、收敛到什么及误差多大都须另证。邻域传播更新局部表示，图信号扩散调整顶点数值，配置查询则汇总变量取值。它们虽然都沿边传递信息，计算对象和目标却不同，不能互相替代。

9.6 本章小结

回到开篇的四顶点图，1 与 4 虽不相邻，却可以经 2 或 3 到达。图保留了这种关系结构，却没有替三元子句保存真值表，也没有决定边是长度、容量还是相似度。无向可达性可以用遍历回答；有向条件分离则须检查全部底层路径的活跃性。祖先道德化为单次查询转换图，只有满足弦图与完美性条件时，才存在保留全部分离答案的固定等价表示。概率独立仍需要相应模型假设。

接口 $\{2, 3\}$ 使左右两侧能够分开计算，但“能够分块”还不够。生成树只保留连接骨架，可能改变距离、环和分离关系；消元保留后续作用域，却可能产生填充。贯穿图先处理 1, 4 的宽度为 2，先处理 2 则增至 3。树分解的运行交集保证接口配置相容。若让最大的袋尽量小，能达到的最优大小就是树宽加一；状态数、因子访问成本和允许的消元次序共同决定实际计算量。

加入目标以后，还须逐项检查最优性的条件。非负边长支持 Dijkstra 永久确定距离，DAG 则依赖无环次序而允许负边；最大流与同值割给出上下界相遇的证书，MST 依靠跨割轻边与树中原边的交换论证，二部匹配利用整数流，二值次模能量利用非负割表示。表 9.2 将这些条件与可核对的输出放在一起。

表 9.2 图查询的目标、关键条件与正确性依据。有限输入编码和数值误差仍须在实现中检查；同一张图可提出多种查询，一种目标的最优解不自动解决其他目标。

问题与算法	关键条件	输出与正确性依据
Dijkstra 最短路	所有边长非负	单源距离与前驱；最小暂定距离的归纳不变量
Bellman-Ford	允许负边；区分可达负环的后继	有限距离、不可达或 $-\infty$ ；有限边数递推与影响范围
最小生成树	无向连通图；成本可正可负	最小总成本连接树；割交换性质
最大流与最小割	非负有限容量、流守恒	可行流与同值割共同认证最优
二部最大匹配	二部图、端点互斥、基数目标	整数单位容量流；无增广路径的割证书
树分解动态规划	运行交集、有限状态、合法半环与次序	精确配置查询；时间指数依赖袋大小，还需计入状态数和运算成本
二值能量最小割	有限一元/成对成本；每个成对项次模	能量与非负割容量仅差常数，返回全局最优配置

若改用松弛和取整寻找近似方案，先检查所得解满足原问题约束，再与有效下界比较。RatioCut 按顶点数平衡，NCut 按度体积平衡，因而松弛后的特征方程不同。连续坐标须取整并回到离散目标核验；上界与下界之差只给出次优差距的上界。

图函数的定义域决定传播在做什么。顶点数值借助图傅里叶坐标按模态变换，多项式滤波限制有限跳数，热扩散则最终保留每个正权支撑分量的平均，可能抹去任务所需差异。顶点标记的 1-WL 细化虽然等变，却不能区分六环与两个三角形；编号无关不等于结构完全可辨。配置函数则依赖半环分配律，由消元与树消息精确汇总内部变量，不能用普通邻域数值聚合替代。

第 8 章利用规则时间或位置索引建立傅里叶表示与卷积，本章再用图连接与沿边能量选择模态和传播规则。环图把两种坐标联系起来，一般图却没有统一平移或天然一致的物理频率，不能直接照搬规则信号的全部性质。后续第 10 章将为权重和观测建立概率描述，第 12 章再区分图的分离判据与概率、生成机制中的独立关系。

第四部分

随机变量、分布与因果响应

Random Variables, Distributions and Causal Responses



阅读指引

一次测量会有误差，不同人群会有不同的数据分布，主动安排培训又可能改变结果的生成方式。这三类问题分别需要随机变量、分布比较和因果响应来描述。本部分沿着它们展开：先建模单个随机量和随机过程，再比较两个分布，最后检查观测关联何时能支持行动后果的判断。

第 10 章“随机变量”建立概率空间上的随机对象、条件关系、分布模型、随机序列与过程，并说明怎样从样本估计未知量、检验假设和评估估计误差。第 11 章“随机分布”把研究对象提升为整个概率分布，讨论信息量、分布差异、最优传输和分布优化，以及参数变化怎样改变分布。第 12 章“因果响应”比较不同安排下的结果，并区分给定模型后的计算、数据能否唯一确定响应，以及怎样推断结果的生成结构。

三章分别处理随机对象、分布之间的关系和机制改变后的响应。条件分布能够描述已观察信息下的不确定性，分布距离能够比较两套规律，但二者都不会自动给出干预结论；因果响应还需要说明行动具体改变什么、结果怎样生成，以及数据怎样收集。

随机变量

同一台传感器重复测量一个稳定信号，读数却不完全相同。怎样描述一次读数的可能取值？两台设备一起测量时，共同的环境扰动怎样改变平均结果？增加测量次数能否消除误差，又能否据此保证下一次读数落在一个窄区间内？这些问题都围绕随机变量展开，但所求的对象并不相同。

要回答这些问题，先要把三件事分开：设备可能处于什么状态、每个状态会产生什么读数、各状态以什么概率出现。本章先把读数规则写成随机变量，再由状态的概率得到读数的分布；随后研究多个读数的关系、重复测量的累计误差和随时间变化的过程。最后，在概率规律未知时，讨论样本能支持怎样的估计、预测与检验。平均值接近真实信号、整条路径接近和区间覆盖未知目标，都需要分别证明。随机噪声怎样进入状态递推、随机积分和状态方程，由第 13 章承接。

10.1 随机变量的定义

描述读数之前，需要明确哪些设备状态可以出现，以及怎样给这些状态组成的事件赋予概率。然后再规定每个状态对应的读数。完整分布给出各个取值范围的概率，均值和方差只概括其中的部分特征；用几个参数描述分布，还要加入模型假设。

10.1.1 概率空间上的随机变量

设一次带噪观测只能取有限个结果 $\Omega = \{\omega_1, \dots, \omega_m\}$ ，并为每个结果指定权重 $p_j \geq 0$ ，满足 $\sum_{j=1}^m p_j = 1$ 。事件 $A \subseteq \Omega$ 的概率为

$$\mathbb{P}(A) = \sum_{\omega_j \in A} p_j.$$

这个有限公式已经包含三条基本规则：概率非负，全集概率为 1，互不相交事件的概率可以相加。一般样本空间可能不可数，而且未必希望给每个子集都赋概率。第 3 章的测度语言恰好把这三条规则推广到这种情形。

定义 10.1 概率空间 概率空间 (probability space) 是三元组 $(\Omega, \mathcal{F}, \mathbb{P})$ 。其中, Ω 是所有可能结果组成的样本空间, $\mathcal{F}$ 是事件组成的 σ 代数, $\mathbb{P} : \mathcal{F} \rightarrow [0, 1]$ 是满足 $\mathbb{P}(\Omega) = 1$ 的测度。可数可加性说明, 对两两不交的事件 $(A_j)_{j \geq 1}$,

$$\mathbb{P}\left(\bigcup_{j \geq 1} A_j\right) = \sum_{j \geq 1} \mathbb{P}(A_j).$$

概率不是附着在口头描述上的数, 而是定义在指定事件族上的测度。若改变 $\mathcal{F}$, 能够询问的事件也会改变。

对事件 A , 其补事件和单调性分别给出

$$\mathbb{P}(A^c) = 1 - \mathbb{P}(A), \quad A \subseteq B \implies \mathbb{P}(A) \leq \mathbb{P}(B).$$

概率测度还与单调极限相容。若 $A_n \uparrow A$, 令 $B_1 = A_1$, $B_n = A_n \setminus A_{n-1}$, 则 (B_n) 两两不交且 $A = \bigcup_n B_n$ 。可数可加性因而给出

$$\mathbb{P}(A) = \sum_{n \geq 1} \mathbb{P}(B_n) = \lim_{n \rightarrow \infty} \mathbb{P}(A_n).$$

若 $A_n \downarrow A$, 对补事件使用上一结论便得到 $\mathbb{P}(A_n) \rightarrow \mathbb{P}(A)$ 。第二个结论用到了 $\mathbb{P}(A_1) \leq 1 < \infty$; 对一般无限测度, 递减连续性必须另外要求起始集合具有有限测度。

如果系统只要有一个部件出错就会失效, 就需要控制“至少一个部件出错”的概率。即使各个出错事件重叠, 也可以先把它们的概率相加, 得到一个保守上界。对任意可数事件族, 这就是联合界

$$\mathbb{P}\left(\bigcup_{j \geq 1} A_j\right) \leq \sum_{j \geq 1} \mathbb{P}(A_j). \quad (10.1)$$

第 10.4.2.2 节会用它同时控制有限候选的误差。现在已有设备状态的概率, 但关心的是读数。需要一条规则, 把每个状态转换成读数, 并保证“读数落在某个范围内”确实是一个能计算概率的事件。

定义 10.2 随机变量 给定可测空间 $(\mathcal{X}, \mathcal{A})$, 若映射 $X : \Omega \rightarrow \mathcal{X}$ 满足 $X^{-1}(B) \in \mathcal{F}$ 对每个 $B \in \mathcal{A}$ 成立, 就称 X 为取值于 $\mathcal{X}$ 的随机变量 (random variable)。

对实值变量, 只需验证

$$\{\omega : X(\omega) \leq x\} \in \mathcal{F}, \quad x \in \mathbb{R},$$

因为这些半无限区间生成 $\mathcal{B}(\mathbb{R})$ 。可测性保证“哪些状态会产生这个范围内的读数”组成 $\mathcal{F}$ 中的事件，因而能够计算概率。随机变量描述的是整条转换规则；某次实验的状态确定后，读数也随之确定。


两台设备同时测量时，可以把两个读数合成一个向量。这样既保留每台设备的读数，也保留它们在同一次实验中的对应关系。

定义 10.3 随机向量 d 维随机向量是从 $(\Omega, \mathcal{F}, \mathbb{P})$ 到 $(\mathbb{R}^d, \mathcal{B}(\mathbb{R}^d))$ 的可测映射 $\mathbf{X} = (X_1, \dots, X_d)^\top$ 。它等价于各坐标可测，不包含坐标相互独立的假设。一般随机对象只需把取值空间换成指定的可测空间。

例如令 $\Omega = \{a, b, c, d\}$ ，四种设备状态等概率出现，规定

ω	a	b	c	d
$X(\omega)$	9	9	11	11
$Y(\omega)$	9	11	9	11

基础结果 b 不是读数 9； X 不是某一次得到的 9，而是整张读数规则。事件 $\{X = 9\} = \{a, b\}$ 的概率为 $1/2$ 。两次使用同一规则不等于两次结果相同，也不自动意味着独立抽样；重复实验的联合规则还要另行给出。图 10.1 把这些层次及未知规律下的推断目标分开。



单次观测： $\omega = b \mapsto X(b) = 9$ ；推送作用于整个概率规律

规律未知：样本 $(x_1, \dots, x_n) \longrightarrow$ 估计目标 $\mathbb{E}X$ 、分位数或分布
同一分布可以由不同基础空间上的映射产生

图 10.1 基础结果经随机变量映射成为读数；把事件概率推送到取值空间得到分布。分布未知时，样本用于估计指定目标，并不能唯一还原基础空间上的映射。

10.1.2 随机变量的分布表示

如果只关心读数，就可以把产生同一读数范围的设备状态汇总起来。由此得到取值空间上的概率测度，称为 X 的分布（distribution）：

$$\mathbb{P}_X(B) = \mathbb{P}(X \in B), \quad B \in \mathcal{B}(\mathbb{R}).$$

分布函数

$$F_X(x) = \mathbb{P}(X \leq x)$$

单调不减、右连续, 并满足 $\lim_{x \rightarrow -\infty} F_X(x) = 0$ 与 $\lim_{x \rightarrow \infty} F_X(x) = 1$ 。反过来, 每个具有这些性质的函数都对应某个实随机变量的分布。

若 $\mathbb{P}_X$ 集中在可数点集上, 可写成概率质量函数 $p_X(x) = \mathbb{P}(X = x)$ 。若它相对于 Lebesgue 测度有密度 f_X , 则

$$\mathbb{P}(X \in B) = \int_B f_X(x) dx, \quad F_X(x) = \int_{-\infty}^x f_X(t) dt.$$

密度值不是单点概率。连续分布通常满足 $\mathbb{P}(X = x) = 0$, 但 $f_X(x)$ 仍可为正; 在密度连续的点, 它等于小邻域概率除以邻域长度后的局部极限; 一般密度只在几乎处处意义下确定, 不能在任意指定点都作这样的解释。例如 X 在区间 $[0, 1/4]$ 上均匀分布时, $f_X(x) = 4\{0 \leq x \leq 1/4\}$ 。密度值 4 可以大于 1, 因为概率由面积而非高度给出: $\mathbb{P}(0.10 \leq X \leq 0.15) = 4 \times 0.05 = 0.2$, 而每个单点的概率仍为 0。

图 10.2 把这一区分放在同一个分布上: 密度图中的矩形面积, 正是分布函数在区间两端的增量。因而从分布函数求区间概率不需要把连续结果变成单点概率。




图 10.2 区间 $[0, 1/4]$ 上的均匀分布 (解析式教学图)。左图阴影为 $[0.10, 0.15]$ 的概率 0.20, 密度高度为 4; 右图的概率是 $F(0.15) - F(0.10)$, 两个端点本身均没有正概率质量。

除了求区间的概率, 还可以反过来问: 阈值至少要取多大, 才能使不超过它的读数占到比例 q ? 分布函数可能有跳跃或平坦段, 因此需要明确怎样选择阈值。 q 分位数 (quantile) 可定义为

$$F^{-1}(q) = \inf\{y : F(y) \geq q\}, \quad 0 < q < 1.$$

这个广义逆为给定的 F 和 q 选出唯一的下分位数。更一般地，所有满足分位数不等式的点组成集合

$$\mathcal{Q}_q = \{a : F(a^-) \leq q \leq F(a)\}.$$

当 F 在水平 q 上存在平坦区间时，这个集合可能包含多个点；上述广义逆约定选取其中的下端代表。

在刚才的四状态例子中，若把基础概率依次改成 $(0.1, 0.2, 0.3, 0.4)$ ，读数规则及取值范围都不变，但 $\mathbb{P}(X = 9)$ 从 $1/2$ 变成 0.3 。所以“能取哪些值”和“以什么概率取值”是两个问题。离散质量是相对于计数测度的密度；连续密度通常相对于 Lebesgue 测度，密度的数值不能脱离参考测度解释。

熟悉的密度以 Lebesgue 测度为参照，概率质量函数以计数测度为参照。两种写法共同的问题是：能否用一个参考测度下的权重表示另一个测度？绝对连续排除参考测度完全看不到的正质量区域，Radon–Nikodym 导数在这一前提下给出权重。换测度随后复用同一个权重公式，而不必对每个分布重新推导积分。

绝对连续与零集兼容性 在有限集合上，两个概率表 (p_j) 与 (q_j) 可以逐项比较。若想用 P 下的样本计算 Q 下的平均，候选权重自然是 q_j/p_j 。但当 $p_j = 0$ 而 $q_j > 0$ 时， P 永远不会产生第 j 个结果，任何有限权重都无法补回这部分质量。

这一障碍在一般空间中由绝对连续刻画：参考测度看不到的集合，目标测度也不能给它正质量。

定义 10.4 测度的绝对连续 设 ν 与 μ 为同一可测空间 $(\Omega, \mathcal{F})$ 上的测度。若

$$\mu(A) = 0 \implies \nu(A) = 0, \quad \text{对所有 } A \in \mathcal{F} \text{ 成立,}$$

则称 ν 对 μ 绝对连续 (absolute continuity)，记作 $\nu \ll \mu$ 。

它只要求 μ 的零集也是 ν 的零集，并不表示 $\nu(A) \leq \mu(A)$ ，也不自动提供有界的密度比。

有限分割上的密度表示 先设 μ 与 ν 为有限测度，取有限可测分割 $\Omega = A_1 \dot{\cup} \cdots \dot{\cup} A_m$ ，并假设 $\nu \ll \mu$ 。对 $\mu(A_j) > 0$ 的分块定义

$$r(\omega) = \frac{\nu(A_j)}{\mu(A_j)}, \quad \omega \in A_j;$$

在 $\mu(A_j) = 0$ 的分块上令 $r = 0$ 。绝对连续性保证后一类分块也满足 $\nu(A_j) = 0$ 。因此, 对任意由这些分块组成的事件 A ,

$$\nu(A) = \int_A r \, d\mu.$$

对在各分块上取有限实常数的函数 g , 逐项相加还给出

$$\int_{\Omega} g \, d\nu = \int_{\Omega} g r \, d\mu. \quad (10.2)$$

一般定理要做的事, 是在没有预先给定有限分块时构造同样的 r^1 。

¹ O. Kallenberg, *Foundations of Modern Probability*, Springer, 2021, 3rd ed.

定理 10.5 Radon-Nikodym 定理 设 μ 与 ν 是 $(\Omega, \mathcal{F})$ 上的 σ 有限测度, 且 $\nu \ll \mu$ 。则存在非负可测函数 r , 使每个 $A \in \mathcal{F}$ 都满足

$$\nu(A) = \int_A r \, d\mu. \quad (10.3)$$

函数 r 在 μ -几乎处处意义下唯一, 记为 $r = d\nu/d\mu$, 称为Radon-Nikodym 导数 (Radon-Nikodym derivative)。

证明. 先设 μ, ν 有限, 并令 $\lambda = \mu + \nu$ 。在线性空间 $L^2(\lambda)$ 上定义

$$T(f) = \int f \, d\nu.$$

由于 $\nu \leq \lambda$, Cauchy-Schwarz 不等式给出

$$|T(f)| \leq \int |f| \, d\nu \leq \nu(\Omega)^{1/2} \left(\int f^2 \, d\nu \right)^{1/2} \leq \nu(\Omega)^{1/2} \|f\|_{L^2(\lambda)}.$$

因此 T 是有界线性泛函。由第 5 章的 Riesz 表示定理, 存在 $g \in L^2(\lambda)$, 使

$$\int f \, d\nu = \int f g \, d\lambda, \quad f \in L^2(\lambda).$$

取 $f = \mathbb{1}_A$ 可得 $\nu(A) = \int_A g \, d\lambda$ 。若 $A = \{g < 0\}$ 具有正测度, 则对集合 $\{g \leq -1/k\}$ 取指示函数会得到 $\nu(\{g \leq -1/k\}) < 0$ 的矛盾, 故 $g \geq 0$ 几乎处处。又因为 $\mu(A) = \lambda(A) - \nu(A) = \int_A (1 - g) \, d\lambda \geq 0$, 同理有 $g \leq 1$ 几乎处处。

令 $C = \{g = 1\}$ 。在 C 上有 $\mu(C) = \int_C (1 - g) \, d\lambda = 0$, 而 $\nu \ll \mu$ 推出 $\nu(C) = 0$ 。另一方面, $\nu(C) = \int_C g \, d\lambda = \lambda(C)$, 所以 $\lambda(C) = 0$ 。于是可以在其余部分定义

$$r = \frac{g}{1 - g},$$

并在 C 上任取值。由 $d\mu = (1 - g) d\lambda$, 对每个 $A \in \mathcal{F}$ 都有

$$\int_A r d\mu = \int_A \frac{g}{1-g} (1-g) d\lambda = \int_A g d\lambda = \nu(A).$$

若 r_1, r_2 都满足该表示, 则对 $A_k = \{r_1 \geq r_2 + 1/k\}$ 有

$$0 = \int_{A_k} (r_1 - r_2) d\mu \geq \frac{1}{k} \mu(A_k),$$

故 $\mu(A_k) = 0$ 。对 k 取并集得到 $r_1 \leq r_2$ 几乎处处; 交换二者即得唯一性。

对 σ 有限的 μ, ν , 分别取有限测度覆盖并求交, 可以把 Ω 写成可数个互不相交、在两种测度下均有限的可测分块。在每个分块上使用上述构造, 再把各块导数拼接, 便得到全空间上的 r 。拼接后的表示可先对有限个分块验证, 再由单调收敛推广到全部分块。 ■

这个证明先让 $\lambda = \mu + \nu$ 同时支配两种测度, 再把测度 ν 表示为 $L^2(\lambda)$ 中的函数 g 。绝对连续性只用于排除 $g = 1$ 承载正质量, 保证比值 $g/(1-g)$ 能够成为相对于 μ 的密度。构造得到的是可测密度, 并没有得到逐点上界。

10.1.3 随机变量的整体特征

若想用一个数概括读数的位置, 有限概率表中最自然的做法是按各读数的概率加权平均。期望把这项运算推广到一般概率空间。它先描述分布下的平均; 样本平均是否接近它, 还要在后面证明。对非负随机变量 X , 定义

$$\mathbb{E}[X] = \int_{\Omega} X(\omega) d\mathbb{P}(\omega).$$

对一般实随机变量, 写 $X = X^+ - X^-$ 。当 $\mathbb{E}[|X|] < \infty$ 时, 正负两部分积分都有限, 此时称 X 可积, 并定义 $\mathbb{E}[X] = \mathbb{E}[X^+] - \mathbb{E}[X^-]$ 。不要求可积便随意相减 $\infty - \infty$ 没有意义。

期望只依赖 X 的分布。对可测函数 g , 只要 $g(X)$ 非负或可积, 就有

$$\mathbb{E}[g(X)] = \int_{\mathbb{R}} g(x) d\mathbb{P}_X(x). \quad (10.4)$$

离散时右侧是 $\sum_x g(x) p_X(x)$, 有密度时则是 $\int g(x) f_X(x) dx$ 。这条“无须先求 $g(X)$ 分布”的积分公式, 会反复用于矩、蒙特卡洛估计和分布变换。

式 (10.4) 直接来自推送测度的定义。对指示函数 $g = \mathbb{I}_B$, 等式两侧分别为 $\mathbb{P}(X \in B)$ 与 $\mathbb{P}_X(B)$, 所以相等。线性地把结论推广到非负简单函数; 任取递增到非负可测 g 的简单函数列, 再在两侧使用单调收敛定理, 即得非负情形。可积实值函数则分别对 g^+ 和 g^- 应用这一结论。这个证明同时说明, 等式并不要求 X 有密度。

示例 10.6 带噪观测的平均目标 设未知信号为 θ ，观测为

$$Y = \theta + \varepsilon, \quad \mathbb{E}[\varepsilon] = 0.$$

只要 ε 可积，就有 $\mathbb{E}[Y] = \theta$ 。这并未说明一次读数接近 θ ，也未说明多个读数的平均必然收敛；后者还需要抽样依赖关系和矩条件。概率模型先把目标写成分布下的平均，后续误差结论再回答有限观测能否逼近这个平均。

可积随机变量的均值记作 $\mu_X = \mathbb{E}[X]$ 。若 $\mathbb{E}[X^2] < \infty$ ，其方差为

$$\text{Var}(X) = \mathbb{E}[(X - \mu_X)^2] = \mathbb{E}[X^2] - \mu_X^2.$$

均值和方差便于计算，却不足以区分许多分布。例如，读数更常向哪一侧偏离均值，或大误差出现得有多频繁，都需要进一步描述。高阶矩考察偏差的更高次幂；生成函数则把各阶矩的关系放进一个函数，便于研究读数相加后的分布。

若 $\mathbb{E}[|X|^k] < \infty$ ，则 $\mathbb{E}[X^k]$ 称为 k 阶原点矩， $\mathbb{E}[(X - \mathbb{E}X)^k]$ 称为 k 阶中心矩。三阶中心矩反映不对称性，四阶中心矩反映尾部与峰度，但有限低阶矩通常不能唯一确定分布。

定义 10.7 矩母函数与累积量生成函数 设 X 为实随机变量。若存在 $\delta > 0$ ，使 $\mathbb{E}e^{tX} < \infty$ 对全部 $|t| < \delta$ 成立，则在该邻域上定义矩母函数 (moment-generating function, MGF) 为

$$M_X(t) = \mathbb{E}[e^{tX}].$$

累积量生成函数 (cumulant-generating function) 是

$$K_X(t) = \log M_X(t).$$

若可在积分号下求导，则 $M_X^{(k)}(0) = \mathbb{E}[X^k]$ 。矩存在却不保证矩母函数在原点邻域有限。取密度为 $e^{-z^2/2}/\sqrt{2\pi}$ 的标准高斯变量 Z ，令 $X = e^Z$ ；这样得到的正随机变量称为对数正态变量 (lognormal random variable)。对每个正整数 k ，配方得到

$$\mathbb{E}X^k = \frac{1}{\sqrt{2\pi}} \int_{\mathbb{R}} e^{kz - z^2/2} dz = e^{k^2/2} < \infty.$$

但对任意 $t > 0$ ，指数矩的被积函数是 $e^{te^z - z^2/2}/\sqrt{2\pi}$ 。当 $z \rightarrow +\infty$ 时， e^z 的增长压过 z^2 ，该被积函数最终大于 1，所以在正半轴上的积分发散。因

此 $\mathbb{E}e^{tX} = \infty$ ，虽有全部正整数阶矩，仍不满足上述邻域条件。累积量生成函数的前两阶导数分别给出均值和方差。对随机向量 $\mathbf{X}$ ，

$$K_{\mathbf{X}}(\mathbf{t}) = \log \mathbb{E}[e^{\mathbf{t}^T \mathbf{X}}],$$

混合偏导数给出联合累积量。独立变量的变换函数乘积及累积量可加法则在第 10.3.1.2 节说明。

前两阶关系可以直接核对。若存在 $\delta > 0$ ，使 $\mathbb{E}e^{tX} < \infty$ 对全部 $|t| < \delta$ 成立，则在更小邻域内， $|X|e^{tX}$ 与 X^2e^{tX} 可由邻域端点的指数函数控制。第 3 章的积分下求导条件于是给出

$$M'_X(t) = \mathbb{E}[Xe^{tX}], \quad M''_X(t) = \mathbb{E}[X^2e^{tX}].$$

因为 $M_X(0) = 1$,

$$K'_X(0) = \frac{M'_X(0)}{M_X(0)} = \mathbb{E}X, \quad K''_X(0) = M''_X(0) - M'_X(0)^2 = \text{Var}(X).$$

矩母函数可能在零点的任何双侧邻域都有限。研究分布极限时，需要一个对所有实参数都存在的变换。

定义 10.8 特征函数 实随机变量 X 的特征函数为 $\varphi_X(t) = \mathbb{E}e^{itX}$ ，其中 $t \in \mathbb{R}$ 。随机向量的版本为 $\varphi_{\mathbf{X}}(\mathbf{t}) = \mathbb{E}e^{i\mathbf{t}^T \mathbf{X}}$ 。复数期望分别对实部与虚部积分。

由于复指数的绝对值恒为 1，特征函数总存在。它用振荡而非指数放大取值，因此与可能发散的矩母函数承担不同职责；后面将用它把独立和的分布极限转成函数的逐点极限。

变换还有一个有限低阶矩所没有的性质：保留完整的特征函数，就保留了分布。

定理 10.9 变换函数的分布唯一性 同维随机向量的特征函数在所有实向量参数上相同，当且仅当它们的分布相同。若两个矩母函数都在原点的某个共同开邻域内有限，并在该邻域内相同，它们也确定相同的分布。

这里引用概率变换的唯一性定理，不展开所需的 Fourier 反演论证²。它把“两个变换相同”转成“两个分布相同”；只比较有限个矩或有限个参数点，没有这种唯一性保证。

² O. Kallenberg, *Foundations of Modern Probability*, Springer, 2021, 3rd ed.

10.1.4 常见取值空间的分布模型

分布模型首先应与观测含义相容：一次成功标记、固定次数中的成功数、等待时间和随机比例具有不同取值空间。取值空间相容仍不代表模型正确，例如非负整数并不自动服从 Poisson 分布；独立性、齐次性和尾部形状都要由问题另行支持。

10.1.4.1 离散取值下的分布模型

一次检测若只记录“成功或失败”，可以用 1 和 0 编码。设成功概率为 $p \in [0, 1]$ ，这种二元结果的分布称为 Bernoulli 分布：

$$\mathbb{P}(X = x) = p^x(1 - p)^{1-x}, \quad x \in \{0, 1\},$$

且 $\mathbb{E}X = p$ 、 $\text{Var}(X) = p(1 - p)$ 。 n 个独立同分布的 Bernoulli 变量之和服从二项分布

$$\mathbb{P}(S = k) = \binom{n}{k} p^k (1 - p)^{n-k}, \quad k = 0, \dots, n,$$

其均值和方差分别为 np 与 $np(1 - p)$ 。

若一次试验有 K 个类别，概率向量 $\mathbf{p}$ 满足 $p_k \geq 0$ 及 $\sum_k p_k = 1$ 。 n 次独立试验的类别计数 $\mathbf{N}$ 服从多项分布，质量为

$$\mathbb{P}(\mathbf{N} = \mathbf{n}) = \frac{n!}{\prod_{k=1}^K n_k!} \prod_{k=1}^K p_k^{n_k}, \quad \sum_{k=1}^K n_k = n.$$

其均值为 $\mathbb{E}N_k = np_k$ ，协方差为 $\text{Cov}(N_j, N_k) = n(p_j \mathbb{I}\{j = k\} - p_j p_k)$ 。

若记录一个固定时间窗口内的告警次数，计数可以是任意非负整数。一个常用候选是参数 $\lambda > 0$ 的 Poisson 分布：

$$\mathbb{P}(N = k) = e^{-\lambda} \frac{\lambda^k}{k!}, \quad k = 0, 1, \dots,$$

且均值、方差都为 λ 。独立计数的相加规律在第 10.3.1.2 节推导。

类别变量 $C \in \{1, \dots, K\}$ 满足 $\mathbb{P}(C = k) = p_k$ ，称为类别分布。类别编号只是标记，编号的均值通常没有物理含义；用独热向量 $\mathbf{e}_C$ 表示时，其均值就是概率向量 $\mathbf{p}$ 。多项分布描述多次独立类别抽取后的整组计数。Poisson 计数没有固定的最大次数；二项计数的上界则是已知试验次数 n 。二者不能只按均值接近就视为同一个模型。

10.1.4.2 连续取值下的分布模型

若关心下一次告警还要等多久，就需要非负连续变量。速率 $\lambda > 0$ 的指数分布是一种等待时间模型，其密度为

$$f_T(t) = \lambda e^{-\lambda t} \mathbb{I}_{\{t \geq 0\}}.$$

其均值为 $1/\lambda$ 、方差为 $1/\lambda^2$ ，并有无记忆性：

$$\mathbb{P}(T > s + t \mid T > s) = \mathbb{P}(T > t).$$

无记忆性只适用于已经等待的时长不改变剩余等待分布，不表示不同等待时间自动独立。它与 Poisson 事件计数的联系在第 10.4.6.3 节给出过程定义后建立。若读数在某个中心两侧波动，希望用中心和波动尺度构造一个对称模型，可以考虑高斯分布（Gaussian distribution，也称正态分布）。记 $X \sim \mathcal{N}(\mu, \sigma^2)$ ，其密度为

$$f_X(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left\{-\frac{(x-\mu)^2}{2\sigma^2}\right\}, \quad \sigma^2 > 0.$$

其均值为 μ ，方差为 σ^2 。当 $a \neq 0$ 时，仿射变换满足 $aX+b \sim \mathcal{N}(a\mu+b, a^2\sigma^2)$ ；当 $a = 0$ 时，结果是集中于 b 的点质量，可记作退化高斯，但不能再使用上面的正方差密度。

正变量上的密度常含有 $x^{a-1}e^{-bx}$ 这一形状。要把它归一化，需要一个依赖形状参数的积分常数。

定义 10.10 Gamma 函数 对实数 $a > 0$ ，定义 Gamma 函数为

$$\Gamma(a) = \int_0^\infty t^{a-1}e^{-t} dt, \quad a > 0. \quad (10.5)$$

$a > 0$ 保证零附近的幂函数可积，指数衰减保证无穷远处可积。分部积分给出 $\Gamma(a+1) = a\Gamma(a)$ ，并且 $\Gamma(1) = 1$ ，所以对正整数 n ，有 $\Gamma(n) = (n-1)!$ 。它把阶乘延伸到这里需要的正实参数，而换元 $t = bx$ 说明 $\int_0^\infty x^{a-1}e^{-bx} dx = \Gamma(a)/b^a$ 。

形状参数 $a > 0$ 、速率参数 $b > 0$ 的 Gamma 分布密度为

$$f_X(x) = \frac{b^a}{\Gamma(a)} x^{a-1} e^{-bx} \mathbb{I}_{\{x > 0\}}.$$

其均值为 a/b ，方差为 a/b^2 。指数分布是 $a = 1$ 的特例。若使用尺度参数 $\vartheta = 1/b$ ，公式会改变；引用 Gamma 分布时必须说明采用速率还是尺度参数。

若 $U \sim \text{Gamma}(a, 1)$ 与 $V \sim \text{Gamma}(b, 1)$ 独立, 则

$$R = \frac{U}{U+V}$$

服从Beta分布 $\text{Beta}(a, b)$ 。为得到归一化常数, 令 $S = U + V$, 于是 $U = RS$ 、 $V = (1 - R)S$, 变换的 Jacobian 绝对值为 s 。独立 Gamma 密度经过换元得到

$$f_{R,S}(r, s) = \frac{r^{a-1}(1-r)^{b-1}}{\Gamma(a)\Gamma(b)} s^{a+b-1} e^{-s}, \quad 0 < r < 1, s > 0.$$

对 s 积分并使用 Gamma 函数定义, 得到

$$f_R(r) = \frac{\Gamma(a+b)}{\Gamma(a)\Gamma(b)} r^{a-1}(1-r)^{b-1} \mathbb{I}_{\{0 < r < 1\}}.$$

因此

$$\mathbb{E}R = \frac{a}{a+b}, \quad \text{Var}(R) = \frac{ab}{(a+b)^2(a+b+1)}.$$

Beta 分布适合描述 $[0, 1]$ 上的随机比例。这里共同速率使比例与总量分离; 两个 Gamma 变量速率不同则不能直接得到该 Beta 结论。

二元成功概率只有一个自由数值; 多类别概率则要同时非负且总和为 1。一种构造方式是先生成正数, 再除以它们的总和。当 $K \geq 2$ 、每个 $\alpha_k > 0$ 时, 独立变量 $G_k \sim \text{Gamma}(\alpha_k, 1)$ 的归一化比例

$$P_k = \frac{G_k}{\sum_{j=1}^K G_j}$$

服从下面定义的 Dirichlet 分布。其均值为 $\mathbb{E}P_k = \alpha_k/\alpha_0$, 其中 $\alpha_0 = \sum_k \alpha_k$ 。同样令 $S = \sum_k G_k$, 把前 $K-1$ 个比例和总量作为新坐标; Jacobian 为 s^{K-1} 。联合密度分成一个形状为 α_0 的 Gamma 密度和一个比例密度。这给出:

定义 10.11 Dirichlet 分布 设 $K \geq 2$ 、 $\alpha_k > 0$ 且 $\alpha_0 = \sum_k \alpha_k$ 。随机向量 $\mathbf{P}$ 取值于概率单纯形, 若以前 $K-1$ 个坐标为自由坐标、令 $p_K = 1 - \sum_{k < K} p_k$, 相对于 $dp_1 \cdots dp_{K-1}$ 的密度为

$$f_{\mathbf{P}}(\mathbf{p}) = \frac{\Gamma(\alpha_0)}{\prod_{k=1}^K \Gamma(\alpha_k)} \prod_{k=1}^K p_k^{\alpha_k-1}, \quad p_k > 0, \quad \sum_k p_k = 1,$$

并在上述自由坐标域以外取零, 就称其服从Dirichlet分布, 记作 $\text{Dirichlet}(\alpha_1, \dots, \alpha_K)$ 。 $K=1$ 时约定为 $P_1 = 1$ 的点质量。

这不是相对于 K 维 Lebesgue 测度的密度：单纯形在该测度下为零集。选定自由坐标，也就明确了归一化常数所对应的参考测度。由 Beta 边缘或直接积分可得

$$\text{Var}(P_k) = \frac{\alpha_k(\alpha_0 - \alpha_k)}{\alpha_0^2(\alpha_0 + 1)}, \quad \text{Cov}(P_j, P_k) = -\frac{\alpha_j \alpha_k}{\alpha_0^2(\alpha_0 + 1)} \quad (j \neq k).$$

负协方差来自各坐标之和固定为 1。例如 Beta(8, 2) 的均值为 0.8、方差为 $16/1100 \approx 0.0145$ ；Beta(80, 20) 均值仍为 0.8，方差降为 $1600/1010000 \approx 0.00158$ 。参数总量增大使质量更集中，却不表示已经观察到相同比例的真实频数；参数如何由数据更新属于第 10.5 节的统计推断问题。Beta 分布是 $K = 2$ 时对一个坐标的描述。

对无约束向量，常用均值为 μ 、协方差为 Σ 的高斯模型。若其协方差 Σ 正定，多元高斯密度为

$$p(\mathbf{x}) = \frac{1}{(2\pi)^{d/2} \det(\Sigma)^{1/2}} \exp \left\{ -\frac{1}{2} (\mathbf{x} - \mu)^\top \Sigma^{-1} (\mathbf{x} - \mu) \right\}.$$

奇异协方差仍定义高斯分布，但它集中在低维仿射子空间上，不具有相对于 d 维 Lebesgue 测度的密度。联合高斯的正式判据将在第 10.2.1 节给出。若 $Z \sim \mathcal{N}(0, 1)$ ，则 (Z, Z) 集中于直线，尽管两个边缘都有一维密度，整体没有二维 Lebesgue 密度。这是参考空间维数的问题，不是分布不存在。若把若干个独立、标准化的高斯误差平方后相加，就得到一个非负的总误差量。下面的分布将用于分析样本残差和方差估计。

定义 10.12 卡方分布 若 $G_1, \dots, G_k$ 相互独立且都服从标准高斯分布 $\mathcal{N}(0, 1)$ ，则称

$$Z = \sum_{j=1}^k G_j^2$$

服从自由度为 k 的卡方分布 (chi-square distribution)，记为 $Z \sim \chi_k^2$ ，其中 k 为正整数。

这里的卡方分布等于采用速率参数的 $\text{Gamma}(k/2, 1/2)$ ，所以均值为 k 、方差为 $2k$ 。独立高斯平方的求和规则在第 10.3.1.2 节回用。

10.1.4.3 参数化分布的指数族表示

Poisson 计数和高斯读数具有不同的取值空间，但其密度中的参数依赖都能集中到少量摘要与一个归一化项。指数族把这种共同结构写出来，使均值、协方差和似然计算能够复用同一组公式。

定义 10.13 指数族 在可测空间上固定一个 σ 有限参考测度 μ , 非负可测基准项 h 和可测向量函数 T 。一类由 η 索引的分布若都被 μ 支配, 且能写成

$$\frac{dP_\eta}{d\mu}(x) = h(x) \exp\{\eta^\top T(x) - A(\eta)\}, \quad (10.6)$$

就称为指数族 (exponential family)。其中 η 是自然参数, $T(x)$ 是充分统计量, $h(x)$ 是基准项。这里“充分”可以先理解为: 样本取值中与参数 η 有关的部分只通过摘要 $T(x)$ 进入密度; 对独立同分布样本, 相应摘要是 $\sum_i T(x_i)$ 。充分性的正式定义与判据留到第 10.5.2.1 节。负责归一化的对数配分函数为

$$A(\eta) = \log \int h(x) e^{\eta^\top T(x)} d\mu(x),$$

自然参数空间由该积分严格为正且有限的参数组成; 所用参数集合可以是这个空间的子集。

离散分布通常取计数测度, 此时积分就是求和; 连续分布通常取 Lebesgue 测度。因而 Poisson 分布与高斯分布都能由同一形式描述, 但使用的参考测度不同。

若 η 位于自然参数空间内部, 并存在可积控制函数允许交换微分与积分, 则

$$\begin{aligned} \nabla A(\eta) &= \frac{\int T(x) h(x) e^{\eta^\top T(x)} d\mu(x)}{\int h(x) e^{\eta^\top T(x)} d\mu(x)} \\ &= \mathbb{E}_\eta[T(X)]. \end{aligned}$$

再求一次导数得到

$$\nabla^2 A(\eta) = \text{Cov}_\eta(T(X)). \quad (10.7)$$

协方差矩阵半正定, 所以 A 凸。若存在非零 $\mathbf{a}$, 使 $\mathbf{a}^\top T(X)$ 几乎处处为常量, 该方向的方差为零, Hessian 矩阵就奇异。这包括某个统计量恒为常量, 以及一个统计量等于其余统计量的线性组合再加常数的情况; 严格凸性并不自动成立。

以 Poisson 分布为例,

$$p_\lambda(x) = \frac{1}{x!} \exp\{x \log \lambda - \lambda\}.$$

自然参数为 $\eta = \log \lambda$, 充分统计量为 $T(x) = x$, $A(\eta) = e^\eta$ 。于是

$$A'(\eta) = e^\eta = \mathbb{E}X, \quad A''(\eta) = e^\eta = \text{Var}(X),$$

与 Poisson 分布的均值、方差一致。

Bernoulli 分布提供另一个核对。令 $\eta = \log(p/(1-p))$, 则

$$p_\eta(x) = \exp\{x\eta - \log(1 + e^\eta)\}, \quad x \in \{0, 1\}.$$

所以 $A(\eta) = \log(1 + e^\eta)$, $A'(\eta) = p$, $A''(\eta) = p(1-p)$ 。对方差已知的高斯分布, $\eta = \mu/\sigma^2$, $T(x) = x$, 而 $A(\eta) = \sigma^2\eta^2/2$, 省略的基准项包含 $\exp\{-x^2/(2\sigma^2)\}$ 。于是 $A'(\eta) = \mu$, $A''(\eta) = \sigma^2$ 。这些例子说明, 产生均值和协方差的是 $\log$ 配分函数 A 的导数, 不是未取对数的归一化常数本身。

10.2 随机变量之间的关系

知道两台设备各自的误差分布, 仍不能确定平均读数的误差: 两台设备可能一起偏高, 也可能互相抵消。本节先描述它们怎样共同变化, 再讨论知道一个读数后怎样更新另一个读数的分布。独立表示两个变量不互相提供额外信息; 可交换表示调换观测编号不会改变联合分布。一个序列可以同时具有这两种性质。

10.2.1 联合关系

随机向量 (X, Y) 的联合分布是映射 $\omega \mapsto (X(\omega), Y(\omega))$ 在乘积空间上诱导的概率测度。离散情形中, 联合质量 $p_{X,Y}(x, y)$ 给出完整表格, 边缘分布由求和消去另一坐标:

$$p_X(x) = \sum_y p_{X,Y}(x, y), \quad p_Y(y) = \sum_x p_{X,Y}(x, y).$$

若联合分布有密度, 则相应运算变为

$$f_X(x) = \int f_{X,Y}(x, y) dy.$$

一般情形不需要质量函数或密度。记坐标投影为 $\pi_X(x, y) = x$, 则边缘分布就是联合分布经 π_X 的推送:

$$\mathbb{P}_X(A) = \mathbb{P}_{(X,Y)}(A \times \mathcal{Y}).$$

对非负可测函数 g , 式 (10.4) 给出

$$\int g(x) \mathbb{P}_X(dx) = \int g(\pi_X(x, y)) \mathbb{P}_{(X,Y)}(dx, dy).$$

若联合分布有密度, 再对右侧使用 Tonelli 定理, 才得到对 y 积分的边缘密度公式。因而“边缘化”首先是测度推送, 求和或积分只是它在特定参考测度下的表达。

边缘化会丢掉变量如何共同变化的信息。两个不同联合分布可以拥有完全相同的两个边缘分布。

对二阶可积的 X, Y , 协方差为

$$\text{Cov}(X, Y) = \mathbb{E}[(X - \mathbb{E}X)(Y - \mathbb{E}Y)].$$

Cauchy-Schwarz 不等式保证它有限。方差满足

$$\text{Var}(aX + b) = a^2 \text{Var}(X),$$

而

$$\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y) + 2 \text{Cov}(X, Y).$$

只有协方差为零时, 方差才直接相加; 独立是协方差为零的充分条件, 但通常不是必要条件。

若各坐标二阶可积, 随机向量的均值和协方差为

$$\boldsymbol{\mu} = \mathbb{E}\mathbf{X}, \quad \boldsymbol{\Sigma} = \mathbb{E}[(\mathbf{X} - \boldsymbol{\mu})(\mathbf{X} - \boldsymbol{\mu})^\top].$$

对任意 $\mathbf{u} \in \mathbb{R}^d$,

$$\mathbf{u}^\top \boldsymbol{\Sigma} \mathbf{u} = \mathbb{E}[(\mathbf{u}^\top (\mathbf{X} - \boldsymbol{\mu}))^2] \geq 0,$$

所以协方差矩阵总是对称半正定。

定义 10.14 多元高斯随机向量 若对每个 $\mathbf{u} \in \mathbb{R}^d$, 标量 $\mathbf{u}^\top \mathbf{X}$ 都服从一维高斯分布, 就称 $\mathbf{X}$ 为多元高斯随机向量 (multivariate Gaussian random vector)。这个定义允许某些线性组合方差为零, 此时相应高斯分布退化为常数。

高斯特征函数可以从一维计算得到。标准高斯密度 $p(z)$ 满足 $p'(z) = -zp(z)$ 。对 $\psi(t) = \int e^{itz} p(z) dz$, 有限一阶绝对矩允许在积分下求导; 再作分部积分, 高斯尾部使边界项消失, 得到

$$\psi'(t) = -i \int_{\mathbb{R}} e^{itz} p'(z) dz = -t\psi(t), \quad \psi(0) = 1.$$

故 $\psi(t) = e^{-t^2/2}$ 。对 $X = \boldsymbol{\mu} + \sigma Z$ 作代入, 便得 $e^{it\boldsymbol{\mu} - \sigma^2 t^2/2}$; $\sigma = 0$ 时常数也满足该式。由多元高斯的定义, $\mathbf{u}^\top \mathbf{X}$ 是一维高斯, 均值和方差分别为 $\mathbf{u}^\top \boldsymbol{\mu}$ 与 $\mathbf{u}^\top \boldsymbol{\Sigma} \mathbf{u}$, 所以

$$\varphi_{\mathbf{X}}(\mathbf{u}) = \exp\{i\mathbf{u}^\top \boldsymbol{\mu} - \frac{1}{2}\mathbf{u}^\top \boldsymbol{\Sigma} \mathbf{u}\}.$$

若两个坐标块的交叉协方差为零, 这个函数分解成两个边缘特征函数的乘积; 乘积测度的特征函数也恰是这个乘积, 定理 10.9 因而说明联合分布等于边缘分布的乘积。这正是后面正式定义的独立性, 也是条件高斯残差计

算的依据。单独的边缘高斯不足以使用这个结论。令 $Z \sim \mathcal{N}(0, 1)$ ，独立符号 S 等概率取 ± 1 ，则 Z, SZ 都标准高斯且协方差为零，却有 $(SZ)^2 = Z^2$ 。它们不独立，也不联合高斯。

把读数转换成二元误差标记 $U, V \in \{0, 1\}$ 。固定边缘规律为

$$U \sim \text{Bernoulli}(1/2), \quad V \sim \text{Bernoulli}(1/2).$$

图 10.3 中的联合质量仍可给出三种不同的平均效果：

	$V = U$	U, V 独立	$V = 1 - U$
$\text{Cov}(U, V)$	1/4	0	-1/4
$\mathbb{P}(U + V = 0)$	1/2	1/4	0
$\mathbb{P}(U + V = 1)$	0	1/2	1
$\mathbb{P}(U + V = 2)$	1/2	1/4	0

完全同向

$U = 0$

$U = 1$

0.5	0
0	0.5

独立

$U = 0$

$U = 1$

0.25	0.25
0.25	0.25

完全反向

$U = 0$

$U = 1$

0	0.5
0.5	0

边缘相同： $\mathbb{P}(U = 1) = \mathbb{P}(V = 1) = 1/2$

图 10.3 边缘质量相同的三个联合分布。格内数字是联合概率，各行各列的和始终为 1/2；质量的位置改变协方差及和的分布。

10.2.2 条件关系

观测没有改变已经发生的读数，但改变了能够利用的信息。只想预测平均值时，条件期望足够；需要尾部概率、分位数或继续抽样时，则需要完整的条件分布。

10.2.2.1 条件期望与信息投影

子 σ 代数 $\mathcal{G} \subseteq \mathcal{F}$ 表示当前可用信息。预测值必须只使用这些信息，又应在每个可识别的分组内保持平均值。

定义 10.15 观测生成的信息 若 $X : \Omega \rightarrow (\mathcal{X}, \mathcal{A})$ 是随机变量, 记 $\sigma(X) = \{X^{-1}(A) : A \in \mathcal{A}\}$. 它是使 X 可测的最小 σ 代数, 表示仅观察 X 能够区分的事件。多个观测生成的信息是包含它们全部可测逆像的最小 σ 代数。

例如只观察分组编号, 就不能在同一组内区分两个原始结果。写 $\mathbb{E}[Y | X]$ 时, 真正限制答案的信息是 $\sigma(X)$, 不是单个零概率事件 $\{X = x\}$ 。

定义 10.16 条件期望 对 $X \in L^1(\mathbb{P})$, 条件期望 (conditional expectation) $\mathbb{E}[X | \mathcal{G}]$ 是满足下列两项条件的可积随机变量 Z :

$$Z \text{ 对 } \mathcal{G} \text{ 可测}, \quad \int_A Z \, d\mathbb{P} = \int_A X \, d\mathbb{P} \quad (A \in \mathcal{G}).$$

第一项要求答案只能使用 $\mathcal{G}$ 中的信息, 第二项要求它在每个可由当前信息识别的事件上保留 X 的平均³。

³ O. Kallenberg, *Foundations of Modern Probability*, Springer, 2021, 3rd ed.

定理 10.17 条件期望的存在与唯一性 若 $X \in L^1(\mathbb{P})$, 则 $\mathbb{E}[X | \mathcal{G}]$ 存在, 并在几乎处处意义下唯一。

证明. 先设 $X \geq 0$. 在 $(\Omega, \mathcal{G})$ 上定义有限测度

$$\nu(A) = \int_A X \, d\mathbb{P}.$$

若 $\mathbb{P}(A) = 0$, 则 $\nu(A) = 0$, 所以 $\nu \ll \mathbb{P}|_{\mathcal{G}}$. Radon-Nikodym 定理给出非负、 $\mathcal{G}$ -可测的 Z , 使 $\nu(A) = \int_A Z \, d\mathbb{P}$. 对一般可积 X , 分别对 X^+ 与 X^- 使用这一构造并取差, 即得存在性。

若 Z_1, Z_2 都满足定义, 令 $D = Z_1 - Z_2$. 对每个 $A \in \mathcal{G}$, $\int_A D \, d\mathbb{P} = 0$. 若 $\mathbb{P}(D > 0) > 0$, 则某个集合 $A_k = \{D \geq 1/k\}$ 具有正概率, 从而

$$\int_{A_k} D \, d\mathbb{P} \geq \frac{1}{k} \mathbb{P}(A_k) > 0,$$

产生矛盾。因此 $D \leq 0$ 几乎处处。交换 Z_1, Z_2 可得 $D \geq 0$ 几乎处处, 故二者几乎处处相等。 ■

积分的线性性与上述唯一性说明, 条件期望也保持线性组合。对非负变量, 存在证明给出的 Radon-Nikodym 导数非负; 因此若 $X \leq Y$ 且两者可积, 对 $Y - X$ 使用该构造便得到 $\mathbb{E}[X | \mathcal{G}] \leq \mathbb{E}[Y | \mathcal{G}]$ 几乎处处。这就是条件期望的保序性。

若 X 本来就对 $\mathcal{G}$ 可测, 则 $\mathbb{E}[X | \mathcal{G}] = X$ 几乎处处。若 X 与 $\mathcal{G}$ 独立, 则条件期望等于常数 $\mathbb{E}[X]$ 。若 U 有界且 $\mathcal{G}$ -可测, 则

$$\mathbb{E}[UX | \mathcal{G}] = U\mathbb{E}[X | \mathcal{G}]. \quad (10.8)$$

可积的非有界 U 需要另外核对乘积可积性, 不能仅凭“已知量可提出”略去条件。

有限分组把抽象定义化成逐组平均。若 $A_1, \dots, A_m$ 是有限可测分割, $\mathcal{G} = \sigma(A_1, \dots, A_m)$, 且每个 $\mathbb{P}(A_j) > 0$, 则

$$\mathbb{E}[X | \mathcal{G}] = \sum_{j=1}^m \frac{\mathbb{E}[X \mathbb{I}_{A_j}]}{\mathbb{P}(A_j)} \mathbb{I}_{A_j}. \quad (10.9)$$

若某个分组概率为零, 该组上的取值可以任意指定, 因为条件期望只在几乎处处意义下唯一。

表 10.1 给出一个可复核例子。令 $\mathcal{G}$ 只能区分 $A = \{\omega_1, \omega_2\}$ 与 $B = \{\omega_3, \omega_4\}$ 。不使用分组信息时, 最佳常数预测是 $U_0 = \mathbb{E}X = 3.4$; 规则 U_{grp} 虽然按组取值, 却随意地在 A, B 上分别预测 0, 4; 条件均值 $m = \mathbb{E}[X | \mathcal{G}]$ 则在两组上分别等于 1.2, 5.6。三列风险依次说明不同问题: 获得分组信息可以优于

结果	概率	X	分组	U_0	U_{grp}	m
ω_1	0.2	0	A	3.4	0	1.2
ω_2	0.3	2	A	3.4	0	1.2
ω_3	0.1	4	B	3.4	4	5.6
ω_4	0.4	6	B	3.4	4	5.6
平方风险 $\mathbb{E}[(X - U)^2]$				5.64	2.80	0.80

表 10.1 有限分组下的三类预测。分组信息使预测可以随 A, B 变化, 但只有逐组条件均值在全部 $\mathcal{G}$ -可测平方可积预测中达到最小平方风险。

无信息常数, 但使用信息本身不保证已经最优; 式 (10.9) 还要在每组内选择正确的条件平均。如果先利用较详细的信息求平均, 再只保留较粗的信息继续平均, 结果应与直接利用较粗信息求平均相同。下面的性质说明两次条件化怎样合并。

定理 10.18 塔式性质 若 $X \in L^1$, 且 $\mathcal{H} \subseteq \mathcal{G} \subseteq \mathcal{F}$, 则

$$\mathbb{E}[\mathbb{E}[X | \mathcal{G}] | \mathcal{H}] = \mathbb{E}[X | \mathcal{H}]$$

几乎处处成立。

证明. 左侧对 $\mathcal{H}$ 可测. 对任意 $A \in \mathcal{H}$, 由于 $A \in \mathcal{G}$, 条件期望定义给出

$$\int_A \mathbb{E}[\mathbb{E}[X | \mathcal{G}] | \mathcal{H}] d\mathbb{P} = \int_A \mathbb{E}[X | \mathcal{G}] d\mathbb{P} = \int_A X d\mathbb{P}.$$

左侧因而满足 X 关于 $\mathcal{H}$ 的条件期望定义, 唯一性给出结论. ■

取 $\mathcal{H} = \{\emptyset, \Omega\}$, 便得到全期望公式 (law of total expectation)

$$\mathbb{E}[\mathbb{E}[X | \mathcal{G}]] = \mathbb{E}[X]. \quad (10.10)$$

这说明条件化改变可用信息, 却不改变再平均后的总体均值。

全方差分解 设 $X \in L^2$, 记 $m = \mathbb{E}[X | \mathcal{G}]$. 分解

$$X - \mathbb{E}X = (X - m) + (m - \mathbb{E}X).$$

在展开平方前, 需要先确认条件均值仍然二阶可积. 对每个有理数 q , 条件期望的线性性与保序性给出

$$\mathbb{E}[X^2 | \mathcal{G}] - 2qm + q^2 = \mathbb{E}[(X - q)^2 | \mathcal{G}] \geq 0.$$

有理数只有可数个, 可以在同一个满测集上同时使用这些不等式. 由于 $\sup_{q \in \mathbb{Q}} (2qm - q^2) = m^2$, 得到

$$|m|^2 \leq \mathbb{E}[X^2 | \mathcal{G}].$$

再取期望并使用全期望公式, 得到

$$\mathbb{E}[m^2] \leq \mathbb{E}[X^2] < \infty.$$

因此 $m \in L^2$, 上面分解中的两项都二阶可积, 其乘积由 Cauchy-Schwarz 不等式保证可积. 又因为第二项对 $\mathcal{G}$ 可测, 而 $\mathbb{E}[X - m | \mathcal{G}] = 0$, 所以交叉项期望为

$$\mathbb{E}[(X - m)(m - \mathbb{E}X)] = \mathbb{E}[(m - \mathbb{E}X)\mathbb{E}[X - m | \mathcal{G}]] = 0.$$

展开平方得到全方差公式 (law of total variance)

$$\text{Var}(X) = \mathbb{E}[\text{Var}(X | \mathcal{G})] + \text{Var}(\mathbb{E}[X | \mathcal{G}]), \quad (10.11)$$

其中

$$\text{Var}(X | \mathcal{G}) = \mathbb{E}[(X - m)^2 | \mathcal{G}].$$

第一项是每个信息分组内部的方差, 再对各组取平均; 第二项是各组条件均值之间的方差. 这是一项统计分解, 并不表示分组变量造成了这些波动。

刚才的平方界是条件 Jensen 不等式 (conditional Jensen inequality) 的一个实例。一般地, 若 $\phi: \mathbb{R} \rightarrow \mathbb{R}$ 为凸函数, X 与 $\phi(X)$ 都可积, 则

$$\phi(\mathbb{E}[X | \mathcal{G}]) \leq \mathbb{E}[\phi(X) | \mathcal{G}] \quad \text{几乎处处.}$$

其依据仍是仿射下界: 在每个有理点选取一条支撑线 $a_q x + b_q \leq \phi(x)$, 凸函数的连续性保证这些支撑线的上确界等于 ϕ 。对每条线取条件期望, 得到 $a_q m + b_q \leq \mathbb{E}[\phi(X) | \mathcal{G}]$, 再在共同满测集上取可数上确界即可。对有限维随机向量, 把支撑线换成仿射支撑超平面, 论证相同; 凸函数只定义在凸域上时, 还需条件均值属于该域, 并核对相关量的可积性。取不含额外信息的平凡条件, 便得到通常的积分 Jensen 不等式。

条件期望的平方损失最优性

定理 10.19 条件均值的平方损失最优性 设 $X \in L^2(\mathbb{P})$ 。在所有 $\mathcal{G}$ -可测且二阶可积的随机变量 U 中,

$$m = \mathbb{E}[X | \mathcal{G}]$$

唯一地在几乎处处意义下最小化 $\mathbb{E}[(X - U)^2]$ 。

证明. $L^2(\mathcal{G})$ 是 $L^2(\mathcal{F})$ 的闭线性子空间, 上文直接证明的条件平方界已经说明 $m \in L^2(\mathcal{G})$ 。对每个 $U \in L^2(\mathcal{G})$, Cauchy-Schwarz 不等式保证 $(X - m)U$ 可积, 因而可以提出已知因子并使用塔式性质, 得到

$$\mathbb{E}[(X - m)U] = \mathbb{E}[U \mathbb{E}[X - m | \mathcal{G}]] = 0.$$

所以 $X - m$ 与整个 $L^2(\mathcal{G})$ 正交。定理 5.10 说明 m 是 X 到该闭子空间的正交投影。也可直接展开

$$\mathbb{E}[(X - U)^2] = \mathbb{E}[(X - m)^2] + \mathbb{E}[(m - U)^2], \quad (10.12)$$

交叉项因正交性消失。第二项非负, 且仅当 $U = m$ 几乎处处时为零。 ■

条件期望的存在只需要 $X \in L^1$, 这时它由 Radon-Nikodym 导数给出。“正交投影”和平方损失最优性则需要 $X \in L^2$ 。若二阶矩无限, 条件期望仍可能存在, 但不能使用 Hilbert 空间几何或有限平方风险。

10.2.2.2 条件分布与概率核

若 X 有连续分布, 事件 $\{X = x\}$ 常有零概率, 便不能用“联合概率除以 $\mathbb{P}(X = x)$ ”求条件分布。需要为每个 x 指定一个分布, 同时保证可以按 X 的概率对这些分布加权平均。概率核正是用来表达这两项要求的。

定义 10.20 概率核 给定可测空间 $(\mathcal{X}, \mathcal{A})$ 、 $(\mathcal{Y}, \mathcal{B})$, 概率核(probability kernel) 是映射

$$K : \mathcal{X} \times \mathcal{B} \rightarrow [0, 1],$$

满足: 对每个 $x \in \mathcal{X}$, $K(x, \cdot)$ 是 $(\mathcal{Y}, \mathcal{B})$ 上的概率测度; 对每个 $B \in \mathcal{B}$, $x \mapsto K(x, B)$ 是 $\mathcal{A}$ -可测函数。

第一项保证每个条件值给出合法分布, 第二项保证再对 X 积分是合法运算。

可测并不等于连续。例如取 $X \sim \mathcal{N}(0, 1)$ 、 $Y = \mathbb{I}\{X \geq 0\}$, 则 $K(x, \{1\}) = \mathbb{I}\{x \geq 0\}$ 是合法概率核在事件 $\{1\}$ 上的取值, 却在 $x = 0$ 处跳变。即使 x 的取值范围是连续的, 条件分布随 x 变化时仍可以跳跃。

定义 10.21 正则条件分布 若概率核 K 对所有 $A \in \mathcal{A}$ 、 $B \in \mathcal{B}$ 满足

$$\mathbb{P}(X \in A, Y \in B) = \int_A K(x, B) \mathbb{P}_X(dx), \quad (10.13)$$

就把 $K(x, \cdot)$ 称为 Y 给定 $X = x$ 的一个正则条件分布 (regular conditional distribution)。

对每个固定可测集 B , 两个版本的 $K(x, B)$ 在 $\mathbb{P}_X$ -几乎处处意义下相同; 若 $\mathcal{Y}$ 是下面的标准 Borel 空间, 还可选取一个共同零测集, 使其外的条件概率测度相同。零概率条件点上的取值通常不能由联合分布唯一决定。

示例 10.22 条件分布版本可以怎样不同 设 $X \sim \text{Unif}[0, 1]$, 并令 $Y = X$ 。给定 x , 取 $K(x, \cdot) = \delta_x$, 即全部条件概率质量集中在 $y = x$ 。对任意 Borel 集 A, B ,

$$\begin{aligned} \mathbb{P}(X \in A, Y \in B) &= \mathbb{P}(X \in A \cap B) \\ &= \int_A \mathbb{I}_B(x) \mathbb{P}_X(dx) = \int_A K(x, B) \mathbb{P}_X(dx). \end{aligned}$$

因此 K 是一个正则条件分布。现在只在 $x = 1/2$ 处把 δ_x 改成 δ_0 , 其余点不变, 得到另一个可测概率核 $\tilde{K}$ 。由于 $\mathbb{P}_X(\{1/2\}) = 0$, 上述积分不变, $\tilde{K}$ 也是同一联合分布的条件版本。两个版本在共同零测集 $\{1/2\}$ 之外给出完全相同的概率测度。

这里每个单点 $\{x\}$ 都有零概率, 却不能因此在所有点上任意改值: 不可数个零概率单点的并集可以具有正概率。若把全部 $K(x, \cdot)$ 都改成 δ_0 , 它就不再重建 $Y = X$ 的联合分布。“几乎处处唯一”约束的是两

个完整条件核可以在哪一整个集合上不同，而不是逐点检查后随意拼接答案。

此例的联合分布全部集中在对角线 $y = x$ 上。对角线的二维 Lebesgue 测度为零，所以不存在普通二维联合密度；正则条件分布仍然存在。条件核因而比密度比值公式更一般。

正则条件分布的存在条件 逐个条件事件的概率能够定义，并不保证它们能拼成一个共同的概率核。下面的可测空间条件为这种拼接提供保证。

定义 10.23 Polish 空间 从一个度量空间出发，允许更换距离但保持同一族开集。若能选到完备且可分的距离，就称这个空间为 Polish 空间。保持开集不变也保持相同的连续映射，这就是“距离与原拓扑兼容”的含义。可分表示含有可数稠密子集；完备性表示所选距离下每个 Cauchy 序列都在空间内收敛。

欧氏空间就是一个例子。这里要求存在合适的距离，不要求最初写下那个距离已经完备。例如 $(0, 1)$ 的通常距离不完备，但连续双射 $x \mapsto \log(x/(1-x))$ 把它映到实轴，逆也连续；拉回实轴距离得到

$$d'(x, y) = \left| \log \frac{x}{1-x} - \log \frac{y}{1-y} \right|.$$

这个距离保持原开集，并把该区间变为与实轴等距的完备可分空间。标准 Borel 空间进一步只保留这样的可测结构。

定义 10.24 标准 Borel 空间 可测空间称为标准 Borel 空间 (standard Borel space)，若它与某个完备可分度量空间的 Borel 子集可测同构，即存在双射，且该双射及其逆映射都可测。

这里不要求展示出来的 Borel 子集在继承距离下完备。若 X 与 Y 的状态空间都是标准 Borel 空间，则上述正则条件分布存在。实数空间、欧氏空间、可数集合以及配备适当 Borel 结构的常见可分函数空间都属于这一范围。

这一存在结论依赖可数生成结构与上一小节的条件期望：需要把逐个事件上的条件平均整理成同一个概率核。

在完全一般的可测空间上，正则条件分布可能不存在。此时条件期望仍可相对于子 σ 代数定义，但不能未经说明就把它写成每个点 x 上的条件密度。后续模型通常工作在标准 Borel 空间中；使用 $p(y | x)$ 时，应同时确认密度所依赖的参考测度及其适用的几乎处处范围。

构造思路可以从可数生成族看清。先在 $\mathcal{Y}$ 的一个可数、能区分概率测度的集合族上, 对每个 B 构造 $\mathbb{P}(Y \in B \mid \sigma(X))$; 再选取这些条件期望关于 X 的可测版本。在去掉一个共同零测集后, 这些数值满足有限可加性和连续性, 扩张定理把它们唯一延拓为 $\mathcal{Y}$ 上的概率测度。标准 Borel 结构提供的可数性和可分性, 正是把逐个事件的版本整理成同一个概率核所需的条件。当 $p_X(x) > 0$ 时, 离散条件质量定义为

$$p_{Y|X}(y \mid x) = \frac{p_{X,Y}(x, y)}{p_X(x)}.$$

因此有乘法公式

$$p_{X,Y}(x, y) = p_X(x)p_{Y|X}(y \mid x).$$

若 $p_Y(y) > 0$, 把联合质量按另一顺序分解便得到 Bayes 公式

$$p_{X|Y}(x \mid y) = \frac{p_{Y|X}(y \mid x)p_X(x)}{\sum_{x'} p_{Y|X}(y \mid x')p_X(x')}. \quad (10.14)$$

分母是观测 y 的边缘概率, 既负责归一化, 也要求观测并非零概率事件。

连续密度公式是同一分解的特例。若 (X, Y) 相对于乘积参考测度有联合密度 $f_{X,Y}$, 且 $0 < f_X(x) < \infty$, 则

$$f_{Y|X}(y \mid x) = \frac{f_{X,Y}(x, y)}{f_X(x)}$$

非负并对 y 积分为 1。它满足 $f_{X,Y}(x, y) = f_X(x)f_{Y|X}(y \mid x)$ 。在 $f_X(x) = 0$ 或 $f_X(x) = \infty$ 的点上, 不能使用这个比值; 这些点构成 $\mathbb{P}_X$ -零测集。条件核在该零测集上可统一指定一个固定概率测度, 而不改变联合分布。这里选用由联合密度积分得到的边缘密度版本; 任意修改过的密度版本也只能保证相应等式几乎处处成立。

示例 10.25 有限候选经过带噪观测更新 设信号只可能是 $\Theta \in \{-1, 1\}$, 先验概率均为 $1/2$ 。传感器以概率 0.8 报告正确符号。观测 $Y = 1$ 后,

$$\mathbb{P}(\Theta = 1 \mid Y = 1) = \frac{0.8 \times 0.5}{0.8 \times 0.5 + 0.2 \times 0.5} = 0.8.$$

观测并未把候选集合改成一个确定点, 而是改变了两个候选的相对权重。若某个观测在所有候选下概率都为零, 公式分母为零, 条件分布不能靠这个比值定义。

设 $\mathbf{X} \sim \mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ 是联合高斯向量。把向量、均值及协方差按相同坐标分块，其中

$$\mathbf{X} = \begin{bmatrix} \mathbf{X}_1 \\ \mathbf{X}_2 \end{bmatrix}, \quad \boldsymbol{\Sigma} = \begin{bmatrix} \boldsymbol{\Sigma}_{11} & \boldsymbol{\Sigma}_{12} \\ \boldsymbol{\Sigma}_{21} & \boldsymbol{\Sigma}_{22} \end{bmatrix},$$

边缘 $\mathbf{X}_1$ 仍为 $\mathcal{N}(\boldsymbol{\mu}_1, \boldsymbol{\Sigma}_{11})$ 。若 $\boldsymbol{\Sigma}_{22}$ 可逆，配方或第 6 章的 Schur 补运算给出

$$\begin{aligned} \mathbf{X}_1 | \mathbf{X}_2 = \mathbf{x}_2 &\sim \mathcal{N}(\boldsymbol{\mu}_1 + \boldsymbol{\Sigma}_{12} \boldsymbol{\Sigma}_{22}^{-1}(\mathbf{x}_2 - \boldsymbol{\mu}_2), \\ &\boldsymbol{\Sigma}_{11} - \boldsymbol{\Sigma}_{12} \boldsymbol{\Sigma}_{22}^{-1} \boldsymbol{\Sigma}_{21}). \end{aligned} \quad (10.15)$$

条件均值是观测的仿射函数，条件协方差不依赖具体观测值。若分块协方差奇异，需要使用广义逆并在支持子空间上解释条件分布，不能直接套用逆矩阵公式。

式 (10.15) 也可由一个独立残差推导。令

$$\mathbf{R} = \mathbf{X}_1 - \boldsymbol{\mu}_1 - \boldsymbol{\Sigma}_{12} \boldsymbol{\Sigma}_{22}^{-1}(\mathbf{X}_2 - \boldsymbol{\mu}_2).$$

直接计算得到 $\text{Cov}(\mathbf{R}, \mathbf{X}_2) = \mathbf{0}$ ，且

$$\text{Cov}(\mathbf{R}) = \boldsymbol{\Sigma}_{11} - \boldsymbol{\Sigma}_{12} \boldsymbol{\Sigma}_{22}^{-1} \boldsymbol{\Sigma}_{21}.$$

$(\mathbf{R}, \mathbf{X}_2)$ 是联合高斯向量，零交叉协方差因而推出独立。给定 $\mathbf{X}_2 = \mathbf{x}_2$ 后， $\mathbf{R}$ 的分布不变，把定义式移项便得到条件均值与条件协方差。

例如令信号 $S \sim \mathcal{N}(0, 4)$ ，观测 $Y = S + \varepsilon$ ，其中 $\varepsilon \sim \mathcal{N}(0, 1)$ 且与 S 独立。于是

$$\text{Cov} \begin{pmatrix} S \\ Y \end{pmatrix} = \begin{bmatrix} 4 & 4 \\ 4 & 5 \end{bmatrix}, \quad S | Y = y \sim \mathcal{N}\left(\frac{4}{5}y, \frac{4}{5}\right).$$

观测到 $y = 2$ 时，条件均值为 1.6，条件方差由先验的 4 降到 0.8。第 13 章的线性高斯滤波会逐时重复这一块条件计算，但还需要动态与观测独立性假设。总分位数来自混合不同输入后的边缘分布；若不同 x 对应不同位置或尾部，还需要按输入报告条件分位数。

定义 10.26 条件分位数 给定 Y 关于 $X = x$ 的正则条件分布，记 $F_x(y) = \mathbb{P}(Y \leq y | X = x)$ 。对 $0 < q < 1$ ，下条件 q 分位数为 $F_x^{-1}(q) = \inf\{y : F_x(y) \geq q\}$ ；完整条件分位数集合为 $\{a : F_x(a^-) \leq q \leq F_x(a)\}$ 。这些对象随条件分布版本确定，并按 P_X -几乎处处意义理解。

条件分位数是已知条件分布的特征；从数据估计整条条件分位函数的方法见第 10.5.2.2 节。

10.2.3 独立关系

独立、不相关与非线性依赖 如果两台设备的噪声互不提供信息，知道第一台的读数就不应改变第二台读数的概率。独立性把这一直觉写成所有取值范围上的乘积关系。若随机变量 X, Y 满足

$$\mathbb{P}(X \in A, Y \in B) = \mathbb{P}(X \in A)\mathbb{P}(Y \in B)$$

对所有 Borel 集合 A, B 成立，就称二者**独立** (independent)。对任意可积的 $g(X)$ 和 $h(Y)$ ，独立性都给出 $\mathbb{E}[g(X)h(Y)] = \mathbb{E}[g(X)]\mathbb{E}[h(Y)]$ 。证明从指示函数开始：独立性正好说明结论对 $g = \mathbb{I}_A$ 、 $h = \mathbb{I}_B$ 成立。线性性把它推广到简单函数，随后分别用单调收敛处理非负函数，再分解正负部分处理乘积可积的实值函数。这里必须要求相关积分有定义，不能把两个发散期望形式相乘。

协方差只检查中心化变量的一次乘积。令 X 在 $[-1, 1]$ 上均匀分布，并取 $Y = X^2$ 。对称性给出

$$\text{Cov}(X, Y) = \mathbb{E}[X^3] - \mathbb{E}[X]\mathbb{E}[X^2] = 0,$$

但 Y 由 X 完全决定；知道 X 便能确定 Y ，所以二者不独立。零协方差只排除了线性二阶关联。

条件独立及其运算规则 两台设备可能共享一个环境状态 Z ，所以整体上相关；但环境状态一旦已知，设备间可能不再有额外依赖。为表达“哪些信息已知后，依赖就消失”，需要条件独立。

定义 10.27 条件独立 给定随机变量 X, Y, Z ，若对 X, Y 取值空间中的所有可测集合 A, B ,

$$\mathbb{P}(X \in A, Y \in B \mid Z) = \mathbb{P}(X \in A \mid Z)\mathbb{P}(Y \in B \mid Z)$$

几乎处处成立，就称 X 与 Y 在给定 Z 时条件独立，记作 $X \perp Y \mid Z$ 。

它表示 Z 已知以后， X 不再提供关于 Y 的额外分布信息；这不意味着去掉 Z 后仍独立。

在多个变量的模型中,经常要把一个条件独立关系拆开,或把几项关系合并。下面的规则说明哪些改写始终有效;条件中的变量不能随意添加或删除。

$$\begin{aligned} X \perp Y | Z &\implies Y \perp X | Z && \text{(对称性)}, \\ X \perp (Y, W) | Z &\implies X \perp Y | Z && \text{(分解)}, \\ X \perp (Y, W) | Z &\implies X \perp Y | Z, W && \text{(弱并)}, \\ X \perp Y | Z, \quad X \perp W | Y, Z &\implies X \perp (Y, W) | Z && \text{(收缩)}. \end{aligned}$$

这些规则可由条件核的乘积分解逐项验证。交性质

$$X \perp Y | Z, W, \quad X \perp W | Z, Y \implies X \perp (Y, W) | Z$$

并非无条件成立;严格为正的有限离散联合质量是一个常用充分条件。若分布把质量集中在低维约束上,零概率组合会阻断所需的消元步骤。

引理 10.28 严格正离散分布的交性质 设 I 为有限索引集, 每个 $i \in I$ 对应取值于有限非空状态空间 $\mathcal{X}_i$ 的随机变量 X_i 。令 p 为 $\mathbf{X} = (X_i)_{i \in I}$ 在乘积状态空间 $\mathcal{X} = \prod_{i \in I} \mathcal{X}_i$ 上的联合质量函数, 且 $p(\mathbf{x}) > 0$ 对所有 $\mathbf{x} \in \mathcal{X}$ 成立。对两两不交的索引集 $A, B, C, D \subseteq I$, 若

$$\mathbf{X}_A \perp \mathbf{X}_B | (\mathbf{X}_C, \mathbf{X}_D), \quad \mathbf{X}_A \perp \mathbf{X}_D | (\mathbf{X}_C, \mathbf{X}_B),$$

则

$$\mathbf{X}_A \perp (\mathbf{X}_B, \mathbf{X}_D) | \mathbf{X}_C.$$

证明. 严格正性保证以下每个条件概率都有定义。对任意取值 $\mathbf{a}, \mathbf{b}, \mathbf{c}, \mathbf{d}$, 两个前提分别给出

$$p(\mathbf{a} | \mathbf{b}, \mathbf{c}, \mathbf{d}) = p(\mathbf{a} | \mathbf{c}, \mathbf{d}), \quad p(\mathbf{a} | \mathbf{b}, \mathbf{c}, \mathbf{d}) = p(\mathbf{a} | \mathbf{b}, \mathbf{c}).$$

因此 $p(\mathbf{a} | \mathbf{c}, \mathbf{d}) = p(\mathbf{a} | \mathbf{b}, \mathbf{c})$ 对每个 $\mathbf{b}, \mathbf{d}$ 成立。固定任意基准值 $\mathbf{b}^\circ$, 右侧等于 $q(\mathbf{a}, \mathbf{c}) = p(\mathbf{a} | \mathbf{b}^\circ, \mathbf{c})$, 不再依赖 $\mathbf{b}$ 或 $\mathbf{d}$ 。对 $(\mathbf{b}, \mathbf{d})$ 关于 $p(\mathbf{b}, \mathbf{d} | \mathbf{c})$ 求和可得 $q(\mathbf{a}, \mathbf{c}) = p(\mathbf{a} | \mathbf{c})$, 故 $p(\mathbf{a} | \mathbf{b}, \mathbf{c}, \mathbf{d}) = p(\mathbf{a} | \mathbf{c})$, 这正是所需的条件独立性。 ■

严格正性使上面证明能在固定 $\mathbf{c}$ 后独立改变 $\mathbf{b}$ 和 $\mathbf{d}$ 。若只支持部分组合, 这一步会失败。一个反例是 $X = Y = W = B$, 其中 B 为非退化 Bernoulli 变量, Z 取常数。给定 W 后 X, Y 都确定, 所以 $X \perp Y | W$; 给定 Y 后也有 $X \perp W | Y$ 。但 X 与 (Y, W) 显然不独立, 因为后者直接给出 X 。两个条件独立前提因而不能在这类带零概率配置的分布上推出交性质。

以分解和收缩为例可以看清这些规则使用了什么。若 $X \perp (Y, W) \mid Z$, 则对任意可测集合 A, B, C , 条件核满足

$$K_{X,Y,W|Z}(A, B, C \mid z) = K_{X|Z}(A \mid z)K_{Y,W|Z}(B, C \mid z).$$

令 C 取全集便得到 $K_{X,Y|Z} = K_{X|Z}K_{Y|Z}$, 这就是分解规则。对收缩规则, 假设

$$K_{X,Y|Z} = K_{X|Z}K_{Y|Z}, \quad K_{X,W|Y,Z} = K_{X|Y,Z}K_{W|Y,Z}.$$

第一个条件还给出 $K_{X|Y,Z} = K_{X|Z}$ 的一个版本。沿条件乘法公式相乘可得

$$K_{X,Y,W|Z} = K_{X|Z}K_{Y|Z}K_{W|Y,Z} = K_{X|Z}K_{Y,W|Z},$$

即 $X \perp (Y, W) \mid Z$ 。所有等式都按相应条件变量分布的几乎处处意义理解。概率图模型部分会在这些概率规则之上另加图分离语义; 图上没有边本身并不是这里定义的条件独立证明。

多元高斯分布是一个特殊情形: 联合高斯随机向量的两个子向量若协方差为零, 则它们独立; 条件高斯中的条件协方差为零也对应条件独立。这个结论依赖联合高斯分布由均值和协方差完全确定, 不能推广到一般分布。

10.2.4 可交换关系

如果一批观测的编号只表示记录顺序, 而不带额外信息, 那么调换编号就不应改变整批观测的联合分布。可交换性描述这种对称; 它不要求各个观测彼此独立。

定义 10.29 可交换随机变量 随机变量 $Z_1, \dots, Z_m$ 若对每个排列 π 都有

$$(Z_1, \dots, Z_m) \stackrel{d}{=} (Z_{\pi(1)}, \dots, Z_{\pi(m)}),$$

就称它们可交换 (exchangeable)。

独立同分布蕴含可交换, 但反向不成立。例如先抽取随机概率 Θ , 再条件于 Θ 独立生成 Bernoulli 观测; 边缘上这些观测可交换, 却因共享 Θ 而相关。

可交换性不提供样本平均的独立乘积结构, 因而不能直接代入 Hoeffding 证明。它提供的是标签位置的对称性: 若评分规则在重排观测时只把分数作同样的重排, 并且分数几乎必然没有并列, 则每个分数占据每个秩的概率都是 $1/m$ 。因为所有标签机会相同, 而每个秩又恰由一个标签占据, 概率总和必须为 1。有并列时, 可为每个分数附加一个服从 $\text{Unif}(0, 1)$ 的随机数, 这些随机数相互独立, 并且独立于全部分数。按“先分数、相同

时再随机数”排序；这保留对称性并消除并列，从而恢复均匀秩。若采用不随机化的并列规则，则通常只能得到相应的保守概率界。后面的共形预测会明确区分这两种处理，使用它们各自的有限样本结论。例如共享参数 $\Theta \sim \text{Beta}(2, 2)$ ，给定 Θ 后 X_i 独立服从 $\text{Bernoulli}(\Theta)$ 。每个边缘的成功率为 $1/2$ ，但对 $i \neq j$ ，塔式性质给出

$$\text{Cov}(X_i, X_j) = \mathbb{E}[\Theta^2] - (\mathbb{E}\Theta)^2 = \text{Var}(\Theta) = \frac{1}{20}.$$

因此 $\mathbb{P}(X_1 = X_2 = 1) = 0.3$ ，大于独立情况下的 0.25 。共享背景使一串成功更常一起出现，却没有偏爱某个观测编号。有限可交换性本身不保证一定存在这样的独立混合表示；本例是可交换依赖的一种构造。

10.3 随机变量的运算与变换

两台传感器的读数相加，是改变取值规则；给定设备状态后再抽取噪声，是加入条件随机生成；保持读数规则却改变设备状态的抽取概率，是改变概率权重。三种操作都能改变输出分布，计算时应先辨明改变的是哪一部分。

10.3.1 确定函数下的变换与组合

“确定”指使用同一条函数规则。输入的取值给定后，输出就唯一确定；输入在不同实验中取值不同，输出仍会随机变化。

10.3.1.1 分布变换的通用规则

若 X 取值于 $(E, \mathcal{E})$ ， $g : E \rightarrow F$ 可测，则 $Y = g(X)$ 的分布是 $P_Y = g_{\#}P_X$ ，即

$$P_Y(B) = P_X(g^{-1}(B)), \quad \mathbb{E}h(Y) = \int_E h(g(x))P_X(dx)$$

对非负可测 h 或可积 h 成立。这个规则不要求密度，也不要求 g 可逆。设 $Y = g(X)$ ，其中 $g : \mathcal{X} \rightarrow \mathcal{Y}$ 为可微双射，逆映射也可微。第3章的换元公式给出

$$f_Y(y) = f_X(g^{-1}(y)) |\det J_{g^{-1}}(y)|. \quad (10.16)$$

Jacobian 矩阵的行列式补偿局部体积变化。只把 $x = g^{-1}(y)$ 代入原密度而漏掉该因子，所得函数通常不能积分为 1。

若映射不是一一对应，需要对所有逆像分支求和。例如 $Y = X^2$ 且 X 有密度时，对 $y > 0$,

$$f_Y(y) = \frac{f_X(\sqrt{y}) + f_X(-\sqrt{y})}{2\sqrt{y}}.$$

若输入和输出的维数不同, Jacobian 不是方阵, 便不能直接使用上述行列式公式。输出能否用密度表示, 要相对于输出空间的参考测度检查绝对连续性; 只要一个零测集承载了正概率, 普通密度表示就会失效。若 (X_1, X_2) 在单位正方形上均匀分布, 投影 $g(x_1, x_2) = x_1$ 降到一维, 输出仍有一维密度 $1_{[0,1]}$, 由对 x_2 积分得到。相反, 嵌入 $h(x) = (x, x)$ 把一维变量放入二维, 像落在直线上, 没有二维 Lebesgue 密度。应比较输出支持与输出空间的维数, 而不能把“降维”直接等同于“没有密度”。

10.3.1.2 数值变量的组合运算

可积变量的和满足 $\mathbb{E}(X + Y) = \mathbb{E}X + \mathbb{E}Y$, 不需要独立; 二阶可积时

$$\text{Var}(aX + bY) = a^2 \text{Var}(X) + b^2 \text{Var}(Y) + 2ab \text{Cov}(X, Y).$$

图 10.3 中三个和的方差依次为 1, 1/2, 0。相同边缘并没有给出相同的累计波动。若只知两个变量可积, 乘积未必可积; 二阶可积则由 Cauchy-Schwarz 保证乘积可积。比值还须确保分母非零, 且另查比值的矩。

若 X, Y 具有联合密度 $f_{X,Y}$, 换元与边缘化给出

$$\begin{aligned} f_{X+Y}(s) &= \int_{\mathbb{R}} f_{X,Y}(x, s-x) dx, \\ f_{XY}(z) &= \int_{\mathbb{R} \setminus \{0\}} f_{X,Y}(x, z/x) \frac{dx}{|x|}, \\ f_{X/Y}(r) &= \int_{\mathbb{R}} |y| f_{X,Y}(ry, y) dy. \end{aligned}$$

后两式的 Jacobian 因子分别为 $1/|x|$ 和 $|y|$ 。独立时联合密度可分解, 和的密度便是卷积 $f_X * f_Y$; 离散和相应使用 $\mathbb{P}(X + Y = s) = \sum_x \mathbb{P}(X = x) \mathbb{P}(Y = s - x)$ 。例如独立标准高斯之比 $R = X/Y$ 满足

$$f_R(r) = \frac{1}{2\pi} \int_{\mathbb{R}} |y| e^{-(1+r^2)y^2/2} dy = \frac{1}{\pi(1+r^2)}.$$

这是标准 Cauchy 密度, $\mathbb{E}|R| = \infty$ 。分子分母都拥有全部矩, 也不保证比值有均值。

独立性还把变换函数化为乘积:

$$\varphi_{X+Y}(t) = \mathbb{E}(e^{itX} e^{itY}) = \varphi_X(t) \varphi_Y(t).$$

在矩母函数共同有限的邻域, 同样有 $M_{X+Y} = M_X M_Y$ 、 $K_{X+Y} = K_X + K_Y$ 。向量的坐标独立时, 联合累积量生成函数按坐标相加, 涉及不同坐标的混合偏导数都为零, 也就是跨坐标累积量为零。若累积量生成函数在原点邻域解析, 所有跨坐标累积量为零又能推出坐标独立: 其 Taylor 展开按坐标分开, 再由变换函数唯一性识别乘积分布。高阶累积量因此可以发现协方

差未反映的非高斯依赖，纯高斯的三阶及以上累积量则为零。独立 Poisson 变量的矩母函数为 $\exp\{\lambda(e^t - 1)\}$ ，相乘后参数相加；独立标准高斯平方的 Gamma 矩母函数相乘，则得到前面定义的卡方分布。

对向量，令 $\mathbf{Y} = \mathbf{A}\mathbf{X} + \mathbf{b}$ ，相应矩存在时

$$\mathbb{E}\mathbf{Y} = \mathbf{A}\boldsymbol{\mu} + \mathbf{b}, \quad \text{Cov}(\mathbf{Y}) = \mathbf{A}\boldsymbol{\Sigma}\mathbf{A}^\top, \quad \text{Cov}(\mathbf{A}\mathbf{X}, \mathbf{B}\mathbf{X}) = \mathbf{A}\boldsymbol{\Sigma}\mathbf{B}^\top.$$

前两条不要求高斯性。若 $\mathbf{X}$ 联合高斯，则任意线性组合仍高斯，因而 $\mathbf{Y} \sim \mathcal{N}(\mathbf{A}\boldsymbol{\mu} + \mathbf{b}, \mathbf{A}\boldsymbol{\Sigma}\mathbf{A}^\top)$ ，即使 $\mathbf{A}$ 不满秩也成立，但不能因此写出非退化密度。

协方差变换式也说明了白化 (whitening) 的含义：对中心化向量作线性变换，使协方差成为单位阵。若 $\boldsymbol{\Sigma} > \mathbf{0}$ ，可取 $\mathbf{Y} = \boldsymbol{\Sigma}^{-1/2}(\mathbf{X} - \boldsymbol{\mu})$ ；此后任何正交旋转 $\mathbf{Q}\mathbf{Y}$ 仍有单位协方差，因为 $\mathbf{Q}\mathbf{I}\mathbf{Q}^\top = \mathbf{I}$ 。因此二阶统计量无法继续辨认这些旋转方向。独立成分分析 (independent component analysis, ICA) 希望从若干源信号的线性混合观测中，辨认相互独立的源。源具有适当的非高斯性时，高阶统计量可以提供白化后仍缺少的方向信息；纯高斯的三阶及以上累积量全为零，不能承担这一任务。这里说明的是高阶信息的用途，并不保证任意三阶、四阶量都足以唯一识别源。

排序也是函数变换。若 $X_1, \dots, X_n$ 独立同分布，分布函数为 F ，则

$$\mathbb{P}(\max_i X_i \leq x) = F(x)^n, \quad \mathbb{P}(\min_i X_i > x) = (1 - F(x))^n,$$

$$\mathbb{P}(X_{(k)} \leq x) = \sum_{j=k}^n \binom{n}{j} F(x)^j (1 - F(x))^{n-j}.$$

这里把“第 k 小不超过 x ”改写成至少 k 个输入不超过 x ，所以出现二项计数。对次序统计量 $Y_{(1)} \leq \dots \leq Y_{(n)}$ ，经验分位数由相应秩位置给出。若 $Y_1, \dots, Y_n$ 是来自连续分布 F 的独立同分布样本，则 $F(Y_{(k)})$ 服从 $\text{Beta}(k, n+1-k)$ ，因此可以用秩而不是高斯近似构造分位数区间。对离散或混合分布，跳跃与平坦区间都要求覆盖计算保留定义中的不等式方向。

10.3.2 条件规则下的随机生成

混合模型先抽取离散指标 Z ，再从分量分布生成 X ：

$$p(x) = \sum_{k=1}^K \mathbb{P}(Z = k) p(x | Z = k).$$

对 Z 求和得到混合密度；观察到 $X = x$ 后再求 $\mathbb{P}(Z = k | X = x)$ ，得到“这个观测来自第 k 个分量”的后验概率，常称为分量责任概率。潜变量只是模型中引入的变量，不必对应可观测的真实类别。

混合分布的方差同时包含分量内和分量间变化。若 $\mathbb{P}(Z = 1) = 1/4$, $\mathbb{P}(Z = 2) = 3/4$, 且

$$X | Z = 1 \sim \mathcal{N}(-1, 1), \quad X | Z = 2 \sim \mathcal{N}(1, 1),$$

则 $\mathbb{E}X = (-1)/4 + 3/4 = 1/2$ 。全方差公式给出

$$\text{Var}(X) = \underbrace{\mathbb{E}[\text{Var}(X | Z)]}_1 + \underbrace{\text{Var}(\mathbb{E}[X | Z])}_{3/4} = \frac{7}{4}.$$

只平均两个分量方差会漏掉均值差造成的 $3/4$ 。

层次模型把参数本身也视为随机变量, 例如

$$\Theta \sim \pi, \quad X_i | \Theta \stackrel{\text{ind}}{\sim} p_{\Theta}.$$

给定 Θ 时, 观测条件独立; 边缘化共同参数后, 观测通常相关。把“条件独立”误写成“边缘独立”会丢掉层次模型中共享不确定性的主要作用。

上面的层次模型让一个参数向量随机; 若不预先固定有限个分量, 也可以让整个概率分布随机。把空间划成有限个区域后, 一个随机分布先表现为各区域的随机概率, 且这些概率之和为 1。有限 Dirichlet 分布正好描述这样的概率向量。要求任意有限分割都具有彼此相容的 Dirichlet 概率向量, 就得到 Dirichlet 过程; 这里增加的是随机对象的范围, 而不是直接把向量维数写成无穷。

定义 10.30 随机概率测度 在可测空间 $(\mathcal{X}, \mathcal{A})$ 上, 先给概率测度空间 $\mathcal{P}(\mathcal{X})$ 配备评价 σ 代数: 它由全部映射 $\mu \mapsto \mu(A)$, $A \in \mathcal{A}$, 生成。随机概率测度就是从底层概率空间到这个可测空间的 measurable 映射; 换言之, 对每个 $A \in \mathcal{A}$, $G(A)$ 都必须是随机变量。

定义 10.31 Dirichlet 过程 设 $(\mathcal{X}, \mathcal{A})$ 为标准 Borel 空间, G_0 为其上的概率测度, $\alpha > 0$ 。随机概率测度 G 称为参数 (α, G_0) 的 Dirichlet 过程, 记作 $G \sim \text{DP}(\alpha, G_0)$, 若对任意有限可测分割 $(A_1, \dots, A_K)$,

$$(G(A_1), \dots, G(A_K)) \sim \text{Dirichlet}(\alpha G_0(A_1), \dots, \alpha G_0(A_K)).$$

其中 $\alpha > 0$ 是总质量参数, G_0 是基概率测度; 若 $G_0(A_k) = 0$, 则相应坐标满足 $G(A_k) = 0$ 几乎必然, 应删除该零参数坐标后理解 Dirichlet 向量。

这一定义要求不同分割给出同一个随机分布的描述: 把两个区域合并时, 区域概率相加, Dirichlet 参数也相加。这样的分割规律称为相容。在

标准 Borel 取值空间上，相容性与扩张定理保证这些有限维规律可由随机概率测度实现。一般抽象空间上的若干随机向量却未必能拼成可数可加的随机测度，因而还须核对随机测度的存在与可测性。后验、聚类表示及非参数 Bayes 计算留给概率模型章节。

10.3.3 概率加权下的分布变换

如果传感器数据按分布 Q 收集，却希望计算分布 P 下的平均，读数本身可以保持不变，改变的是每条读数对平均的贡献。前面的 Radon–Nikodym 导数给出所需权重；下面先证明它怎样作用于一般积分，再检查权重过大或缺少覆盖时的限制。

定理 10.32 换测度积分公式 若 $\nu \ll \mu$, $r = d\nu/d\mu$, 则对每个非负可测函数 g ,

$$\int g d\nu = \int gr d\mu.$$

只要 g 在 ν 下可积，同一等式也对实值 g 成立。

证明. 对指示函数 $g = \mathbb{I}_A$, 结论就是 Radon–Nikodym 表示。由线性性, 它对非负简单函数成立。任取非负可测 g , 选择简单函数 $g_n \uparrow g$, 分别在 ν 和 μ 下使用单调收敛定理即可。对可积实值函数, 再分别处理 g^+ 与 g^- 。■

密度比存在、有界和具有有限二阶矩是三项不同条件。若 $P \ll Q$, 则 $w = dP/dQ$ 存在且 $\mathbb{E}_Q[w] = 1$, 但这不推出 $\|w\|_\infty < \infty$, 也不推出 $\mathbb{E}_Q[w^2] < \infty$ 。例如在 $(0, 1)$ 上令 Q 为均匀分布, 取

$$w(x) = \frac{1}{2\sqrt{x}}.$$

它的积分为 1, 所以定义一个 $P \ll Q$; 但 w 无界, 且 $\int_0^1 w(x)^2 dx = \infty$ 。换测度恒等式仍成立, 使用该权重的蒙特卡洛估计却可能没有有限方差。

有限表可以直接核对权重方向。设参考分布 Q 在三个结果上的概率为 $(0.5, 0.4, 0.1)$, 目标分布 P 为 $(0.2, 0.3, 0.5)$, 则

$$w = \frac{dP}{dQ} = (0.4, 0.75, 5).$$

对取值 $g = (1, 2, 4)$, 有

$$\mathbb{E}_P[g] = 2.8 = 0.5(0.4)(1) + 0.4(0.75)(2) + 0.1(5)(4) = \mathbb{E}_Q[wg].$$

第三个结果在 Q 下少见, 却在 P 下承载一半质量, 所以产生大权重。若把参考概率 0.1 改成 0 而保持目标概率 0.5, 则 $P \not\ll Q$, 任何重加权都无法从 Q 样本恢复这部分目标质量。

图 10.4 显示, 权重改变的是每个结果对平均的贡献, 而不是把观测值 g_j 解释为概率。未加权平均为 1.7, 加权平均为 2.8; 第三个结果的贡献从 0.4 增至 2, 也预示它偶尔出现时会显著推动估计值。




图 10.4 三结果换测度的有限构造。左图比较采样分布 Q 与目标分布 P , 右图比较 $q_j g_j$ 与 $q_j w_j g_j = p_j g_j$ 。各柱从零起画; 右图柱高之和分别为 1.7 和 2.8, 并非单点概率。

绝对连续性也决定几乎处处结论能否转移。若 $P \ll Q$, 且 $|g| \leq M$ 在 Q 下几乎处处成立, 则违背上界的集合是 Q -零集, 因而也是 P -零集; 同一上界在 P 下仍成立。反向转移需要 $Q \ll P$, 不能只凭 $P \ll Q$ 得到。若 $|g| \leq B$, 则

$$\mathbb{E}_Q[w^2 g^2] \leq B^2 \mathbb{E}_Q[w^2],$$

所以权重二阶矩有限是有界被积函数获得有限重加权方差的充分条件。把权重截为 $w_c = \min\{w, c\}$ 会限制波动, 但 $\mathbb{E}_Q[w_c g]$ 与 $\mathbb{E}_P[g]$ 之差为 $-\mathbb{E}_Q[(w - c)_+ g]$, 一般不为零。

同样的重加权还可以用于每个信息分组内的平均。但权重不仅改变各结果的贡献, 也改变每个分组的总概率, 因而需要在组内重新归一化。以下公式把 P 记作参考分布、 Q 记作目标分布, 权重相应改记为 $L = dQ/dP$ 。设 $Q \ll P$, 并记 $L = dQ/dP$ 。对 $X \in L^1(Q)$, 在 $\mathbb{E}_P[L | \mathcal{G}] > 0$ 处有

$$\mathbb{E}_Q[X | \mathcal{G}] = \frac{\mathbb{E}_P[LX | \mathcal{G}]}{\mathbb{E}_P[L | \mathcal{G}]} \quad (10.17)$$

为验证这个候选变量确实是条件期望, 记

$$D = \mathbb{E}_P[L | \mathcal{G}], \quad N = \mathbb{E}_P[LX | \mathcal{G}],$$

并在 $\{D > 0\}$ 上令 $Z = N/D$, 在 $\{D = 0\}$ 上令 $Z = 0$ 。分母零集在 Q 下可以忽略, 因为

$$Q(D = 0) = \mathbb{E}_P[L\{D = 0\}] = \mathbb{E}_P[D\{D = 0\}] = 0.$$

条件期望的单调性还给出

$$|N| \leq \mathbb{E}_P[L|X| \mid \mathcal{G}].$$

在 $\{D = 0\}$ 上, 非负变量 $L\{D = 0\}$ 的期望为零, 因而 $L = 0$ 几乎处处。于是

$$\mathbb{E}_P[\mathbb{E}_P[L|X| \mid \mathcal{G}]\{D = 0\}] = \mathbb{E}_P[L|X|\{D = 0\}] = 0,$$

上面的条件三角不等式进而说明 $N = 0$ 在 $\{D = 0\}$ 上几乎处处成立。因此 $DZ = N$ 几乎处处, 而且

$$\begin{aligned} \mathbb{E}_Q[Z] &= \mathbb{E}_P[L|Z|] = \mathbb{E}_P[D|Z|] \\ &= \mathbb{E}_P[|N|\{D > 0\}] \leq \mathbb{E}_P[L|X|] = \mathbb{E}_Q[X] < \infty. \end{aligned}$$

这里把 $\mathcal{G}$ -可测的非负因子 $|Z|$ 提出条件期望, 可以由有界截断和单调收敛得到。候选变量的可积性建立后, 对 $A \in \mathcal{G}$ 可合法地计算

$$\begin{aligned} \int_A Z \, dQ &= \int_A ZL \, dP = \int_A Z \mathbb{E}_P[L \mid \mathcal{G}] \, dP \\ &= \int_A \mathbb{E}_P[LX \mid \mathcal{G}] \, dP = \int_A LX \, dP = \int_A X \, dQ. \end{aligned}$$

因此 Z 满足 X 在 Q 下关于 $\mathcal{G}$ 的条件期望定义。公式(10.17)是 Bayes 更新的一般测度形式; 分母零集与候选变量可积性都需要像上面这样核对。

用有限分组可以看出分母为何不可省略。设参考分布 P 把四个结果 $\omega_1, \dots, \omega_4$ 分别赋予概率 $(0.4, 0.1, 0.1, 0.4)$, 目标分布 Q 赋予 $(0.1, 0.5, 0.1, 0.3)$ 。令信息 $\mathcal{G}$ 只区分 $A = \{\omega_1, \omega_2\}$ 和 A^c , 并令 $X = (0, 1, 0, 1)$ 。权重 L 在四点上的值为 $(0.25, 5, 1, 0.75)$ 。在 A 内,

$$\mathbb{E}_P[LX \mid \mathcal{G}] = \frac{0.5}{0.5} = 1, \quad \mathbb{E}_P[L \mid \mathcal{G}] = \frac{0.1 + 0.5}{0.5} = 1.2,$$

所以目标条件均值为 $1/1.2 = 5/6$, 与 $\mathbb{E}_Q[X \mid A] = 0.5/(0.1 + 0.5)$ 一致。省略分母却会得到 1, 可以直接看到重新归一化改变了答案。在 A^c 内, 分子为 $0.3/0.5 = 0.6$, 分母为 $0.4/0.5 = 0.8$, 相除得到 $3/4$, 也等于该组在 Q 下的条件均值。条件化后必须按每个信息分组的目标总质量分别归一化。对一串有限观测 $X_1, \dots, X_n$, 可以按历史 $x_{< i}$ 逐步比较两个规律。若在每一步给定历史后, 两个条件分布都相对于同一参考测度定义密度 (参考测度可

随历史改变), 分别记为 $p_i(x_i | x_{<i})$ 、 $q_i(x_i | x_{<i})$, 且初始及逐步目标核对来源核绝对连续, 则

$$\frac{dQ}{dP}(x_{1:n}) = \prod_{i=1}^n \frac{q_i(x_i | x_{<i})}{p_i(x_i | x_{<i})} \quad P\text{-几乎处处.}$$

每个比值都要条件可测, 并在实际可能到达的历史上归一化; 对 P 不可能产生而 Q 可能产生的观测, 不能用有限权重补救。此式只依赖联合分布的链式分解, 不预设 Markov 性。核因子何时可以相消, 在第 10.4.5.1 节另行核对。

10.4 随机序列和随机过程

重复观测使问题从单个变量变成变量族。固定样本量时, 要控制和、平均或整组候选的误差; 样本量增长时, 要规定极限的含义。把索引进一步解释为时间, 还需描述历史信息与整条路径, 不能只盯着每一时刻的边缘分布。

10.4.1 随机序列

定义 10.33 随机序列 同一概率空间上的可测映射族 $(X_n)_{n \in \mathbb{N}}$ 称为随机序列 (random sequence)。固定 n 得到一个随机变量, 固定 ω 得到确定的实现序列 $(X_n(\omega))_{n \in \mathbb{N}}$ 。取值空间可以是实数、向量或其他指定可测空间。

例如独立噪声 (ε_i) 、共享背景的读数 $X_i = \Theta + \varepsilon_i$ 和累计和 $S_n = \sum_{i=1}^n \varepsilon_i$ 都是随机序列, 但具有不同的联合关系。前者可独立, 中者共享 Θ , 后者相邻项共享此前的全部增量。即使各项边缘相同, 也不能据此选用独立样本平均的结论。这里 n 可以是试验编号; 当它表示物理时间或算法轮次时, 历史信息的解释才进一步进入模型。

10.4.2 随机序列的聚合

有限样本误差回答“现有 n 次观测是否足够”。下面先对一个累计量给出概率界, 再对候选族同时控制, 最后把这些工具用于积分计算。后续极限定理不会自动给出这些有限样本常数。

10.4.2.1 累计量的概率误差

先问一个基本问题：若只知道非负误差的平均大小，能否限制误差超过阈值 a 的概率？超过阈值的结果每次至少贡献 a ，所以它们不能占据过大概率。若 $X \geq 0$ ，则对 $a > 0$,

$$\mathbb{P}(X \geq a) \leq \frac{\mathbb{E}X}{a}. \quad (10.18)$$

证明只需写 $\mathbb{E}X \geq \mathbb{E}[X\mathbb{I}\{X \geq a\}] \geq a\mathbb{P}(X \geq a)$ 。这就是 Markov 不等式。对均值 μ 、方差 $\sigma^2 < \infty$ 的随机变量，把 Markov 不等式用于 $(X - \mu)^2$ ，得到 Chebyshev 不等式

$$\mathbb{P}(|X - \mu| \geq t) \leq \frac{\sigma^2}{t^2}, \quad t > 0. \quad (10.19)$$

它只使用二阶矩，因而适用范围广，但没有利用有界性或指数矩信息。对任意 $\lambda > 0$ ，函数 $x \mapsto e^{\lambda x}$ 单调。Markov 不等式给出

$$\mathbb{P}(X \geq t) = \mathbb{P}(e^{\lambda X} \geq e^{\lambda t}) \leq e^{-\lambda t} \mathbb{E}[e^{\lambda X}]. \quad (10.20)$$

随后对 λ 优化，便得到 Chernoff 方法。整个方法依赖相应指数矩有限；若 $\mathbb{E}e^{\lambda X} = \infty$ ，式 (10.20) 虽形式上仍真，却不给出有用上界。

中心化高斯变量的指数矩恰为 $\exp(\lambda^2 \sigma^2 / 2)$ 。如果其他变量的指数矩不超过这个值，就也能用同一个 Chernoff 计算得到高斯形状的尾部上界。

定义 10.34 次高斯变量 对 $\sigma^2 > 0$ ，均值为零的可积实随机变量 X 若满足

$$\mathbb{E}[e^{\lambda X}] \leq \exp\left(\frac{\lambda^2 \sigma^2}{2}\right), \quad \lambda \in \mathbb{R},$$

就称它为参数 σ^2 的次高斯变量 (sub-Gaussian random variable)。

代入 Chernoff 界并取 $\lambda = t/\sigma^2$ ，得到

$$\mathbb{P}(X \geq t) \leq \exp\left(-\frac{t^2}{2\sigma^2}\right).$$

“次高斯”约束的是指数矩，从而控制尾部，不要求变量服从高斯分布。这里 σ^2 是上界中的尺度参数，也不必等于变量的实际方差。

有界变量的 Hoeffding 不等式

引理 10.35 Hoeffding 引理 若 $\mathbb{E}X = 0$ 且 $X \in [a, b]$ 几乎处处成立, 则

$$\mathbb{E}[e^{\lambda X}] \leq \exp\left\{\frac{\lambda^2(b-a)^2}{8}\right\}, \quad \lambda \in \mathbb{R}.$$

证明. 若 $a = b$, 均值为零迫使 $X = 0$, 结论直接成立。以下设 $a < b$ 。凸性说明, 对 $x \in [a, b]$, 指数函数位于连接端点的弦下方:

$$e^{\lambda x} \leq \frac{b-x}{b-a}e^{\lambda a} + \frac{x-a}{b-a}e^{\lambda b}.$$

取期望并使用 $\mathbb{E}X = 0$ 。令 $p = -a/(b-a) \in [0, 1]$ 、 $s = \lambda(b-a)$, 则右侧的对数为

$$\psi(s) = \log[(1-p)e^{-ps} + pe^{(1-p)s}].$$

这里对无量纲变量 s 求导。写 $r_s = pe^s/(1-p+pe^s)$, 直接求导得到 $\psi''(s) = r_s(1-r_s) \leq 1/4$, 且 $\psi(0) = \psi'(0) = 0$ 。Taylor 积分余项给出 $\psi(s) = s^2 \int_0^1 (1-u)\psi''(us) du \leq s^2/8$, 对正负 s 都成立。代回原变量, 便有

$$\log \mathbb{E}[e^{\lambda X}] \leq \frac{\lambda^2(b-a)^2}{8}.$$

指数化即得结论。 ■

定理 10.36 Hoeffding 不等式 设 $X_1, \dots, X_n$ 相互独立, 且 $X_i \in [a_i, b_i]$ 几乎处处成立。则对 $t > 0$,

$$\mathbb{P}\left(\sum_{i=1}^n (X_i - \mathbb{E}X_i) \geq t\right) \leq \exp\left\{-\frac{2t^2}{\sum_{i=1}^n (b_i - a_i)^2}\right\}.$$

证明. 记 $S = \sum_i (X_i - \mathbb{E}X_i)$ 。对 $\lambda > 0$, 独立性使指数矩分解:

$$\begin{aligned} \mathbb{P}(S \geq t) &\leq e^{-\lambda t} \mathbb{E}[e^{\lambda S}] \\ &= e^{-\lambda t} \prod_{i=1}^n \mathbb{E}[e^{\lambda(X_i - \mathbb{E}X_i)}] \\ &\leq \exp\left\{-\lambda t + \frac{\lambda^2}{8} \sum_{i=1}^n (b_i - a_i)^2\right\}. \end{aligned}$$

右侧关于 λ 的最小点为

$$\lambda^* = \frac{4t}{\sum_i (b_i - a_i)^2}.$$

代回即得结论。对 $-S$ 使用同一结果, 再用联合界可得双侧版本。 ■

若 $X_i \in [0, 1]$ 独立, 则样本平均满足

$$\mathbb{P}(|\bar{X}_n - \mathbb{E}\bar{X}_n| \geq \varepsilon) \leq 2e^{-2n\varepsilon^2}.$$

有界性进入 Hoeffding 引理, 独立性进入矩母函数乘积; 删除任一条件都不能沿用这份证明。

方差敏感的 Bernstein 不等式 Hoeffding 界只使用可能取值的范围。若变量通常远比最坏范围稳定, 就希望让上界也反映实际方差。设独立中心化变量满足 $|X_i| \leq M$, 并记 $v = \sum_i \mathbb{E}[X_i^2]$, Bernstein 不等式的一个版本为

$$\mathbb{P}\left(\sum_{i=1}^n X_i \geq t\right) \leq \exp\left\{-\frac{t^2}{2(v + Mt/3)}\right\}. \quad (10.21)$$

为看清两个尺度的来源, 取 $0 < \lambda < 3/M$ 。由指数级数及 $|X_i|^k \leq M^{k-2}X_i^2$ ($k \geq 2$), 有

$$\mathbb{E}e^{\lambda X_i} \leq 1 + \frac{\lambda^2 \mathbb{E}X_i^2}{2(1 - \lambda M/3)} \leq \exp\left\{\frac{\lambda^2 \mathbb{E}X_i^2}{2(1 - \lambda M/3)}\right\}.$$

这里第一阶项因中心化而消失, 常数 $1/3$ 来自用几何级数控制

$$\sum_{k \geq 3} \frac{(\lambda M)^{k-2}}{k!}.$$

独立性使各指数矩相乘, Chernoff 步骤于是给出

$$\mathbb{P}\left(\sum_i X_i \geq t\right) \leq \exp\left\{-\lambda t + \frac{\lambda^2 v}{2(1 - \lambda M/3)}\right\}.$$

取 $\lambda = t/(v + Mt/3)$ 便得到式 (10.21)。小偏差区域由 v 主导, 呈高斯型; 大偏差区域由 Mt 主导, 呈指数型。

例如 $B_i \sim \text{Bernoulli}(0.01)$ 独立, 考虑 $\bar{B}_n - 0.01 \geq 0.05$ 。Hoeffding 上界为 $\exp(-0.005n)$, 而 Bernstein 上界约为

$$\exp\left\{-\frac{0.05^2 n}{2(0.01 \times 0.99 + 0.05/3)}\right\} \approx \exp(-0.047n).$$

低发生率使实际方差远小于区间最坏尺度, 所以后者明显更紧; 当方差接近区间允许的最大值或偏差进入线性尺度时, Bernstein 并不保证处处优于 Hoeffding。

对重尾变量, 方差可能不存在, 指数矩也可能对所有正参数发散。此时 Chebyshev、Hoeffding 和 Bernstein 各自在矩、范围或指数矩步骤失效。可以增加截断、稳健均值或仅用有限 p 阶矩推导多项式尾界, 但所得估计对象和偏差需要重新说明, 不能继续声称高斯型集中。

10.4.2.2 候选族的共同误差

一个候选的误差小，不保证由同一数据选中的候选误差也小。若要允许选择，应先在同一概率事件上控制全部候选。候选索引与样本索引在这里并存，不能把“每个固定候选都成立”误读成“所有候选同时成立”。

有限候选的联合控制 设有限候选类 $\mathcal{H} = \{h_1, \dots, h_M\}$ ，损失 $\ell(h, Z) \in [0, 1]$ 。真实风险与经验风险分别为

$$R(h) = \mathbb{E}[\ell(h, Z)], \quad \hat{R}_n(h) = \frac{1}{n} \sum_{i=1}^n \ell(h, Z_i),$$

其中 $Z_1, \dots, Z_n$ 独立同分布。对预先固定的单个 h ，Hoeffding 不等式给出

$$\mathbb{P}(|\hat{R}_n(h) - R(h)| > \varepsilon) \leq 2e^{-2n\varepsilon^2}.$$

但经验最优候选 $\hat{h} \in \arg \min_h \hat{R}_n(h)$ 由同一批数据选出，不是预先固定对象。只控制一个候选不能排除“恰好因噪声看起来最好”的选择偏差。

为明确“同时控制”与“样本量足够”的关系，把上述要求写成一个定义。这里讨论抽样前固定的函数类；所有上确界均假定可测。一项常用充分条件是存在可数子类，使每个函数都是该子类中某个序列的逐点极限。

定义 10.37 分布无关的一致收敛 设 $\mathcal{G}$ 是非空的 $[0, 1]$ 值可测函数类。若对任意 $\eta, \delta \in (0, 1)$ ，存在只依赖 $\mathcal{G}, \eta, \delta$ 的整数 n_0 ，使任意概率分布 P 和任意 $n \geq n_0$ 的独立同分布样本 $S = (Z_1, \dots, Z_n) \sim P^n$ 均满足

$$\mathbb{P}_{S \sim P^n} \left\{ \sup_{g \in \mathcal{G}} \left| \frac{1}{n} \sum_{i=1}^n g(Z_i) - \mathbb{E}_P g \right| \leq \eta \right\} \geq 1 - \delta, \quad (10.22)$$

就称 $\mathcal{G}$ 满足分布无关的一致收敛 (uniform convergence)。若只要求 P 属于指定分布族，同一定义给出相对于该分布族的一致收敛。

“函数上一致”由上确界表达，“分布无关”则要求同一个 n_0 适用于全部允许分布。对每个固定函数或每个固定分布分别存在的样本量，不能自动满足这两个量词。

定理 10.38 有限函数类的一致误差界 在上述条件下，对任意 $\delta \in (0, 1)$ ，以至少 $1 - \delta$ 的概率同时对所有 $h \in \mathcal{H}$ 有

$$|\hat{R}_n(h) - R(h)| \leq \sqrt{\frac{\log(2M/\delta)}{2n}}. \quad (10.23)$$

证明. 对每个 h 定义坏事件

$$A_h = \{|\hat{R}_n(h) - R(h)| > \varepsilon\}.$$

单函数 Hoeffding 界给出 $\mathbb{P}(A_h) \leq 2e^{-2n\varepsilon^2}$. 由联合界,

$$\mathbb{P}\left(\bigcup_{h \in \mathcal{H}} A_h\right) \leq 2Me^{-2n\varepsilon^2}.$$

令右侧等于 δ , 解得 $\varepsilon = \sqrt{\log(2M/\delta)/(2n)}$. 在坏事件并集的补集上, 结论对全部候选同时成立. ■

令 $h^* \in \arg \min_h R(h)$, 并在式(10.23)成立的事件上记右侧为 ε_n . 则

$$\begin{aligned} R(\hat{h}) &\leq \hat{R}_n(\hat{h}) + \varepsilon_n \\ &\leq \hat{R}_n(h^*) + \varepsilon_n \\ &\leq R(h^*) + 2\varepsilon_n. \end{aligned}$$

第二步正是经验最优性的用途。候选数只通过 $\log M$ 进入, 但若候选类本身由同一数据任意生成, 简单地把最终数量代入 M 未必合法; 需要把生成过程纳入统一控制对象。例如 $M = 100$ 、 $n = 1000$ 、 $\delta = 0.05$ 时, 式(10.23)右侧约为

$$\sqrt{\frac{\log 4000}{2000}} \approx 0.0644.$$

这个数同时控制一百个预先固定候选, 而不是给每个候选各自提供 95% 保证; 后一做法的联合失败概率可能远大于 5%。

同时控制有限个对象的误差, 还可用于随机投影: 希望把许多高维点投到较少坐标上, 并保留各点间的距离。高斯投影后的平方长度与一组标准高斯平方和成比例, 因此先要控制卡方变量偏离均值的概率。

引理 10.39 χ^2 变量的尾界 若 $Z \sim \chi_k^2$, 其中 k 为正整数, 则对每个 $x > 0$,

$$\mathbb{P}\{Z - k \geq 2\sqrt{kx} + 2x\} \leq e^{-x}, \quad \mathbb{P}\{k - Z \geq 2\sqrt{kx}\} \leq e^{-x}.$$

因而对 $0 < \varepsilon < 1$,

$$\mathbb{P}\left(\left|\frac{Z}{k} - 1\right| > \varepsilon\right) \leq 2 \exp\left(-\frac{k\varepsilon^2}{8}\right). \quad (10.24)$$

证明. 标准高斯积分给出 $\mathbb{E}e^{\lambda G^2} = (1 - 2\lambda)^{-1/2}$, $\lambda < 1/2$ 。独立性因而给出

$$\log \mathbb{E}e^{\lambda(Z-k)} = \frac{k}{2}\{-2\lambda - \log(1 - 2\lambda)\} \leq \frac{k\lambda^2}{1 - 2\lambda}, \quad 0 < \lambda < 1/2.$$

最后一步来自 $-u - \log(1 - u) = \sum_{j \geq 2} u^j/j \leq u^2/[2(1 - u)]$ 。对上尾使用 Chernoff 方法, 取 $\lambda = \sqrt{x}/(\sqrt{k} + 2\sqrt{x})$, 便在阈值 $2\sqrt{kx} + 2x$ 处得到指数 $-x$ 。对下尾, 用 $u - \log(1 + u) \leq u^2/2$ 得到

$$\log \mathbb{E}e^{-\lambda(Z-k)} \leq k\lambda^2, \quad \lambda > 0.$$

取 $\lambda = \sqrt{x/k}$, 在阈值 $2\sqrt{kx}$ 处也得到指数 $-x$ 。最后取 $x = k\varepsilon^2/8$ 。当 $0 < \varepsilon < 1$ 时, 两侧阈值均不超过 $k\varepsilon$, 故相对偏差事件包含于对应尾事件的并集, 联合界给出式 (10.24)。 ■

有了单个向量平方长度的集中界, 就可以对每一对点的差向量使用它, 再用联合界保证所有距离同时保持。这一结果称为 Johnson–Lindenstrauss 引理: 保留有限个距离所需的随机投影维数主要随点数的对数增长, 而不由原始坐标数直接决定。

定理 10.40 高斯随机投影的距离保持 给定抽样前固定的 $N \geq 2$ 个点 $\mathbf{x}_1, \dots, \mathbf{x}_N \in \mathbb{R}^d$, 以及 $\varepsilon, \delta \in (0, 1)$ 。若 $\mathbf{A} \in \mathbb{R}^{k \times d}$ 的元素独立服从 $\mathcal{N}(0, 1/k)$, 且

$$k \geq \frac{8}{\varepsilon^2} \log \frac{N(N-1)}{\delta},$$

则以至少 $1 - \delta$ 的概率, 对全部 i, j 同时有

$$(1 - \varepsilon)\|\mathbf{x}_i - \mathbf{x}_j\|_2^2 \leq \|\mathbf{A}\mathbf{x}_i - \mathbf{A}\mathbf{x}_j\|_2^2 \leq (1 + \varepsilon)\|\mathbf{x}_i - \mathbf{x}_j\|_2^2. \quad (10.25)$$

证明. 固定一个不依赖 $\mathbf{A}$ 的非零向量 $\mathbf{v}$ 。矩阵各行独立, 每个 $(\mathbf{A}\mathbf{v})_r$ 均为均值零、方差 $\|\mathbf{v}\|_2^2/k$ 的高斯变量, 因此

$$\frac{k\|\mathbf{A}\mathbf{v}\|_2^2}{\|\mathbf{v}\|_2^2} \sim \chi_k^2.$$

引理 10.39 使该方向的相对平方范数失真概率不超过 $2e^{-k\varepsilon^2/8}$ 。点对差至多有 $N(N-1)/2$ 个; 对全部非零差使用联合界, 失败概率不超过 $N(N-1)e^{-k\varepsilon^2/8} \leq \delta$ 。零差经任何线性投影仍为零, 无须额外尾界。 ■

结论控制的是平方距离; 对距离本身开方后, 因子为 $\sqrt{1 \pm \varepsilon}$ 。点集须在投影抽样前确定, 但在同时保持事件上, 可以事后任选这批点中的一对查询。它不保证对观察到 $\mathbf{A}$ 后任意新造的向量都保持范数; 当 $k < d$ 时, $\mathbf{A}$

的非零零空间方向就给出反例。这里的常数是便于推导的充分界，也不保证所得 k 一定小于 d 。

无限候选的统一控制 无限函数类不能直接按元素做联合界。第 2.1 节建立的取值模式与第 5.2.3 节建立的覆盖数提供两种有限化方法。使用样本取值模式时，须先引入独立样本副本并进行下文的对称化，再条件于两批合并样本。此时随机符号和只由样本上的有限取值模式决定，才可对模式使用条件尾界和联合界。同一个样本模式可能对应不同的真实风险，因此不能直接把前面固定候选界中的 M 换成当前样本的模式数。使用覆盖网时，若每个函数都能由有限 ε -网中的代表逼近，则先控制网点，再用 Lipschitz 性质把误差转回原函数。下面先建立后一种方法所需的误差比较，再说明对称化怎样引入随机符号。

引理 10.41 覆盖数的有限网控制 设 $(\mathcal{F}, d)$ 具有有限 ε -网 $\mathcal{N}_\varepsilon$ ，其大小为 $N(\mathcal{F}, d, \varepsilon)$ 。若随机过程 $\{Z_f : f \in \mathcal{F}\}$ 满足

$$|Z_f - Z_g| \leq Ld(f, g)$$

几乎处处对所有 f, g 成立，并且相关上确界可测，则对任意 $t > 0$,

$$\mathbb{P} \left\{ \sup_{f \in \mathcal{F}} |Z_f| > t + L\varepsilon \right\} \leq N(\mathcal{F}, d, \varepsilon) \sup_{f \in \mathcal{F}} \mathbb{P}(|Z_f| > t). \quad (10.26)$$

证明. 对每个 f 选取满足 $d(f, g_f) \leq \varepsilon$ 的 $g_f \in \mathcal{N}_\varepsilon$ 。则

$$|Z_f| \leq |Z_{g_f}| + L\varepsilon,$$

所以左侧坏事件包含在 $\bigcup_{g \in \mathcal{N}_\varepsilon} \{|Z_g| > t\}$ 中。对这个有限并集使用联合界即得结论。 ■

若 $Z_f = \hat{R}_n(f) - R(f)$ ，且经验风险与真实风险各自关于 d 都是 L_0 -Lipschitz，则引理中的过程常数是 $2L_0$ 。因此，网格大小、离散误差 $2L_0\varepsilon$ 和单点尾界必须一起进入结论；只报告覆盖数而不验证 Lipschitz 传递还不能控制原函数类。

有些目标不是单个样本平均，而是整个数据集的函数 $F(Z_1, \dots, Z_n)$ 。若替换第 i 个输入最多改变 c_i ，即

$$\sup_{z, z'_i} |F(z_1, \dots, z_i, \dots, z_n) - F(z_1, \dots, z'_i, \dots, z_n)| \leq c_i,$$

则独立输入下的 McDiarmid 不等式给出

$$\mathbb{P}(F - \mathbb{E}F \geq t) \leq \exp \left\{ -\frac{2t^2}{\sum_{i=1}^n c_i^2} \right\}. \quad (10.27)$$

其证明把 F 依次对前 i 个观测条件化, 形成 Doob 鞅; 每步有界差控制一个鞅增量, 再使用 Hoeffding 型指数矩界。独立性保证逐步揭示观测时的条件结构, 有界差则限制单个观测的影响。McDiarmid 不等式的完整证明见第 10.4.5.3 节: 在那里把数据函数逐步揭示为 Doob 鞅, 并说明独立输入为什么给出所需的条件范围。有限候选可按数量控制误差; 无限类的函数在同一组观测上可能高度相似, 直接计数会忽略这种结构。Rademacher 复杂度提供另一种衡量方式: 固定观测点后, 让函数尽量对齐一组无信号的随机正负号, 再对这些正负号平均。能拟合更多随机起伏的类, 需要更大的同时误差代价。

定义 10.42 经验 Rademacher 复杂度 给定非空实值可测函数类 $\mathcal{G}$ 和样本 $S = (z_1, \dots, z_n)$ 。令 σ_i 独立且等概率取 $-1, 1$ 。当上确界可测且期望有限时, 经验 Rademacher 复杂度定义为

$$\hat{\mathfrak{R}}_S(\mathcal{G}) = \mathbb{E}_\sigma \left[\sup_{g \in \mathcal{G}} \frac{1}{n} \sum_{i=1}^n \sigma_i g(z_i) \right]. \quad (10.28)$$

固定的是样本, 不是使随机和最大的函数; 每一组符号都允许选择不同函数。交换上确界与期望会把所有固定函数的零均值随机和平均成零, 丢掉所要衡量的拟合能力。

定义 10.43 期望 Rademacher 复杂度 对 $S \sim P^n$, 期望 Rademacher 复杂度定义为

$$\mathfrak{R}_n(\mathcal{G}) = \mathbb{E}_{S \sim P^n} \hat{\mathfrak{R}}_S(\mathcal{G}).$$

期望复杂度还平均了抽样结果, 故依赖 P ; 经验复杂度仅依赖给定样本上的函数取值。允许函数作凸组合会增加候选函数, 却未必增加它们对随机符号的最大对齐能力。原因在于, 固定符号后, 经验随机和是函数取值的线性泛函: 若一个组合的各项都不超过同一个上界, 非负且归一化的加权平均也不能超过它。下面把这一几何性质写成复杂度恒等式。

定理 10.44 凸组合的 Rademacher 复杂度 设 $S = (z_1, \dots, z_n)$ 为固定样本, $n \geq 1$, $\mathcal{B}$ 为非空实值可测函数类, 且在这组样本上统一有界, 即存在有限 M 使 $|h(z_i)| \leq M$ 对所有 $h \in \mathcal{B}$ 和 i 成立。令

$$\text{conv}(\mathcal{B}) = \left\{ \sum_{t=1}^T a_t h_t : T \geq 1, h_t \in \mathcal{B}, a_t \geq 0, \sum_{t=1}^T a_t = 1 \right\}$$

为全部有限凸组合构成的函数类。则

$$\hat{\mathfrak{R}}_S(\text{conv}(\mathcal{B})) = \hat{\mathfrak{R}}_S(\mathcal{B}).$$

若样本再按 P^n 抽取, 几乎必然满足上述样本有界条件, 且相应样本上确界可测、期望有限, 则期望 Rademacher 复杂度也满足同一恒等式。

证明. 固定一组符号 σ . 对任意有限凸组合, 由 $a_t \geq 0$ 和 $\sum_t a_t = 1$,

$$\begin{aligned} \frac{1}{n} \sum_{i=1}^n \sigma_i \sum_{t=1}^T a_t h_t(z_i) &= \sum_{t=1}^T a_t \left(\frac{1}{n} \sum_{i=1}^n \sigma_i h_t(z_i) \right) \\ &\leq \sup_{h \in \mathcal{B}} \frac{1}{n} \sum_{i=1}^n \sigma_i h(z_i). \end{aligned}$$

因此凸包上的上确界不超过基类上的上确界。反向不等式来自 $\mathcal{B} \subseteq \text{conv}(\mathcal{B})$: 取 $T = 1$ 即可得到任意基函数。于是每一组符号下的两个上确界都相等。样本上的统一有界性保证随机和与其上确界有限, 对 σ 取期望使得经验复杂度恒等式; 在额外的抽样可测性与可积条件下, 再对 S 取期望即得期望复杂度结论。证明不要求函数类有限, 也不要求上确界由某个函数达到。 ■

例如, 只含常值函数 0 和 1 的基类, 其凸包包含全部常值 $c \in [0, 1]$ 。固定一个观测点时, 正号下的最大随机和为 1, 负号下为 0, 两类的经验复杂度都为 $1/2$ 。候选函数从两个增加到无穷多个, 但线性随机和的最坏值仍由端点决定。这一定理只控制实值函数的随机线性和; 把组合再作阈值化等非线性变换后, 需要另外分析变换后的函数类。非负性与归一化也是凸组合的条件, 不能用同一等式处理任意符号或任意尺度的线性组合。

定义 10.45 经验高斯复杂度 将随机符号换成独立标准高斯系数 $\xi_i \sim \mathcal{N}(0, 1)$, 定义

$$\hat{\mathfrak{G}}_S(\mathcal{G}) = \mathbb{E}_\xi \left[\sup_{g \in \mathcal{G}} \frac{1}{n} \sum_{i=1}^n \xi_i g(z_i) \right].$$

相应期望高斯复杂度为 $\mathfrak{G}_n(\mathcal{G}) = \mathbb{E}_S \hat{\mathfrak{G}}_S(\mathcal{G})$ 。

高斯系数的符号与幅度都变化, Rademacher 系数只有符号变化。二者是关于函数类的随机平均, 不能按某一组系数的最大值直接比较。

双侧误差的证明常使用带绝对值版本

$$\hat{\mathfrak{R}}_S^{\text{abs}}(\mathcal{G}) = \mathbb{E}_\sigma \sup_{g \in \mathcal{G}} \left| \frac{1}{n} \sum_i \sigma_i g(z_i) \right| = \hat{\mathfrak{R}}_S(\mathcal{G} \cup (-\mathcal{G})),$$

高斯版本同样定义。只有当 $\mathcal{G} = -\mathcal{G}$ 时, 两种约定才可直接等同。例如只含常数函数 $g \equiv 1$ 的类, 其不带绝对值复杂度为 0; 带绝对值复杂度为 $n^{-1} \mathbb{E} |\sum_i \sigma_i| > 0$ 。以下对称化沿用带绝对值约定, 后续应用单侧风险界时应核对所用版本。

对称化与随机函数复杂度 设 $\mathcal{F}$ 是一族取值于 $[-1, 1]$ 的函数, 定义

$$\Delta(\mathbf{Z}) = \sup_{f \in \mathcal{F}} \left| \mathbb{E} f(\mathbf{Z}) - \frac{1}{n} \sum_{i=1}^n f(Z_i) \right|.$$

引入独立同分布副本 $Z'_1, \dots, Z'_n$ 。Jensen 不等式给出

$$\mathbb{E}_{\mathbf{Z}, \mathbf{Z}'} \Delta(\mathbf{Z}) \leq \mathbb{E}_{\mathbf{Z}, \mathbf{Z}'} \sup_{f \in \mathcal{F}} \left| \frac{1}{n} \sum_{i=1}^n (f(Z'_i) - f(Z_i)) \right|.$$

由于每对 (Z_i, Z'_i) 交换后联合分布不变, 引入独立 Rademacher 符号 $\sigma_i \in \{-1, 1\}$ 不会改变差的联合分布。因此

$$\mathbb{E} \Delta(\mathbf{Z}) \leq 2 \mathbb{E}_{\mathbf{Z}, \boldsymbol{\sigma}} \sup_{f \in \mathcal{F}} \left| \frac{1}{n} \sum_{i=1}^n \sigma_i f(Z_i) \right|.$$

右侧是带绝对值的经验 Rademacher 复杂度对样本取期望后的两倍。它只在观测点上考察函数类与随机符号对齐的能力, 把未知总体期望转成了条件于样本的随机和。

若 $\phi_i : \mathbb{R} \rightarrow \mathbb{R}$ 均为 L -Lipschitz 且 $\phi_i(0) = 0$, 则对任意不必关于取负封闭的函数类 $\mathcal{F}$, 带绝对值的收缩不等式为

$$\mathbb{E}_\sigma \sup_{f \in \mathcal{F}} \left| \sum_i \sigma_i \phi_i(f(Z_i)) \right| \leq 2L \mathbb{E}_\sigma \sup_{f \in \mathcal{F}} \left| \sum_i \sigma_i f(Z_i) \right|.$$

一般情形需要先在取值向量类中临时加入零向量, 再分别控制随机和的两个方向; 这一步产生因子 2。若变换后的取值向量类关于取负封闭, 例如 $\mathcal{F} = -\mathcal{F}$ 且每个 ϕ_i 都是奇函数, 则可去掉该因子。这个不等式允许把预测函数的复杂度传到 Lipschitz 损失。若损失不全局 Lipschitz 或相关上确界不可积, 必须限制作用范围或使用其他矩条件。

标量收缩可用逐坐标替换证明。先设函数类在固定样本上的取值向量组成有限集 $\mathcal{A} \subset \mathbb{R}^n$, 并只考虑不带绝对值的上确界。固定前 $n-1$ 个符号, 把相应部分记为 $U_{\mathbf{a}}$ 。条件于这些符号, 左侧最后一个坐标的贡献为

$$\frac{1}{2} \sup_{\mathbf{a}} \{U_{\mathbf{a}} + \phi_n(a_n)\} + \frac{1}{2} \sup_{\mathbf{a}} \{U_{\mathbf{a}} - \phi_n(a_n)\}.$$

取两个上确界的近似最大元 $\mathbf{a}, \mathbf{b}$, 并使用 $\phi_n(a_n) - \phi_n(b_n) \leq L|a_n - b_n|$ 。按 $a_n - b_n$ 的符号选择正负方向, 便得到上式不超过

$$\frac{1}{2} \sup_{\mathbf{a}} \{U_{\mathbf{a}} + La_n\} + \frac{1}{2} \sup_{\mathbf{a}} \{U_{\mathbf{a}} - La_n\}.$$

从最后一个坐标向前迭代, 即得到单侧收缩。对随机和的正、负两个方向分别应用该结论, 再用 $\sup |S| = \max\{\sup S, \sup(-S)\}$ 时, 还需要保证两个单侧上确界非负。具体地, 令 $\mathcal{A}_0 = \mathcal{A} \cup \{\mathbf{0}\}$ 。由于 $\phi_i(0) = 0$, 对每组固定符号都有

$$\sup_{\mathbf{a} \in \mathcal{A}} \left| \sum_i \sigma_i \phi_i(a_i) \right| \leq \sup_{\mathbf{a} \in \mathcal{A}_0} \sum_i \sigma_i \phi_i(a_i) + \sup_{\mathbf{a} \in \mathcal{A}_0} \left(- \sum_i \sigma_i \phi_i(a_i) \right).$$

两个单侧上确界因包含零向量而非负。分别对 σ 与 $-\sigma$ 应用单侧收缩, 再利用二者同分布, 得到

$$\mathbb{E}_{\sigma} \sup_{\mathbf{a} \in \mathcal{A}} \left| \sum_i \sigma_i \phi_i(a_i) \right| \leq 2L \mathbb{E}_{\sigma} \sup_{\mathbf{a} \in \mathcal{A}_0} \sum_i \sigma_i a_i \leq 2L \mathbb{E}_{\sigma} \sup_{\mathbf{a} \in \mathcal{A}} \left| \sum_i \sigma_i a_i \right|.$$

因此带绝对值版本也得到了证明。一般函数类可由有限子类逼近并使用单调极限; 不可数类还须保留前述可测性条件。

线性函数类展示了这一复杂度怎样落到熟悉的范数上。设

$$\mathcal{F} = \{\mathbf{z} \mapsto \langle \mathbf{w}, \mathbf{z} \rangle : \|\mathbf{w}\|_2 \leq B\}, \quad \|\mathbf{Z}_i\|_2 \leq R.$$

由对偶范数和 Jensen 不等式,

$$\begin{aligned} \hat{\mathfrak{R}}_{\mathbf{Z}}^{\text{abs}}(\mathcal{F}) &= \frac{B}{n} \mathbb{E}_{\sigma} \left\| \sum_{i=1}^n \sigma_i \mathbf{Z}_i \right\|_2 \\ &\leq \frac{B}{n} \left(\sum_{i=1}^n \|\mathbf{Z}_i\|_2^2 \right)^{1/2} \leq \frac{BR}{\sqrt{n}}. \end{aligned}$$

参数范数、样本范数和样本量分别进入 B 、 R 与 $n^{-1/2}$ 。机器学习理论部分会在具体损失和模型类上继续把这一期望复杂度转换为高概率泛化界。

把 Rademacher 符号替换为独立标准高斯变量 g_i ，得到高斯复杂度

$$\mathbb{E}_{\mathbf{g}} \sup_{f \in \mathcal{F}} \left| \frac{1}{n} \sum_i g_i f(Z_i) \right|.$$

记上述带绝对值的经验 Rademacher 复杂度和高斯复杂度分别为 $\hat{\mathfrak{R}}_{\mathbf{Z}}^{\text{abs}}(\mathcal{F})$ 与 $\hat{\mathfrak{G}}_{\mathbf{Z}}^{\text{abs}}(\mathcal{F})$ 。对任意固定样本，只要这些上确界可测且期望有限，就有单向比较

$$\hat{\mathfrak{R}}_{\mathbf{Z}}^{\text{abs}}(\mathcal{F}) \leq \sqrt{\frac{\pi}{2}} \hat{\mathfrak{G}}_{\mathbf{Z}}^{\text{abs}}(\mathcal{F}).$$

这个方向可直接由条件 Jensen 不等式解释：写 $g_i = \sigma_i |g_i|$ ，符号与幅度独立，且 $\mathbb{E}|g_i| = \sqrt{2/\pi}$ 。固定符号后，随机和的绝对值上确界是幅度向量的凸函数，先对幅度平均不大于先取上确界再平均，因而 $\hat{\mathfrak{G}}_{\mathbf{S}}^{\text{abs}} \geq \sqrt{2/\pi} \hat{\mathfrak{R}}_{\mathbf{S}}^{\text{abs}}$ 。

反过来，要用 Rademacher 复杂度控制高斯复杂度，所需倍数可能随样本量和函数类改变。设函数类在固定样本上的取值向量恰为 $\{\mathbf{e}_i, -\mathbf{e}_i : 1 \leq i \leq n\}$ ，其中 $\mathbf{e}_i$ 为第 i 个坐标向量。两个上确界分别化为

$$\hat{\mathfrak{R}}_{\mathbf{Z}}^{\text{abs}} = \frac{1}{n}, \quad \hat{\mathfrak{G}}_{\mathbf{Z}}^{\text{abs}} = \frac{\mathbb{E} \max_{i \leq n} |g_i|}{n}.$$

符号的绝对值恒为 1，高斯幅度的最大值却随 n 增长。其尺度可直接核对：对任意 $t > 0$ ，指数和上界及 Jensen 不等式给出

$$\mathbb{E} \max_i |g_i| \leq \frac{\log(2n)}{t} + \frac{t}{2} \leq \sqrt{2 \log(2n)} \quad \text{当 } t = \sqrt{2 \log(2n)}.$$

下界取 $u = \sqrt{\log n} \geq 1$ 。在高斯密度积分中只保留区间 $[u, u + 1/u]$ ，得到 $\mathbb{P}(|g_1| \geq u) \geq c u^{-1} e^{-u^2/2}$ ，其中 $c > 0$ 为固定常数。于是独立性给出

$$\mathbb{P}(\max_i |g_i| \geq u) \geq 1 - \exp\{-cn^{1/2}/\sqrt{\log n}\} \rightarrow 1.$$

用期望下界 $u \mathbb{P}(\max_i |g_i| \geq u)$ 可知，两种复杂度的比为 $\Theta(\sqrt{\log n})$ ($n \geq 2$ ，有限个小 n 并入常数)。因此替换复杂度时必须保留比较方向；这个例子已经排除了普适常数的反向界。

10.4.2.3 采样平均的积分近似

很多期望无法直接算出闭式表达式，但可以从相应分布采样。此时先把每个样本代入被积函数，再取平均，就把积分问题转成了样本平均的误差问题。目标积分可统一写成

$$I = \mathbb{E}_P[f(X)].$$

若能独立采样 $X_i \sim P$, 直接蒙特卡洛估计为

$$\hat{I}_n = \frac{1}{n} \sum_{i=1}^n f(X_i).$$

当 $\mathbb{E}_P|f(X)| < \infty$ 时, 线性性给出无偏性; 若方差 $\sigma_f^2 < \infty$, 则

$$\text{Var}(\hat{I}_n) = \frac{\sigma_f^2}{n}.$$

长期一致性和缩放误差分布在第 10.4.3.3 节统一核验。误差的标准差按 $n^{-1/2}$ 下降, 与输入维数没有显式关系, 但 σ_f^2 可能随问题结构急剧增大。

以下固定教学积分

$$I = \int_0^1 x^2 dx = \frac{1}{3}.$$

若 $X \sim \text{Unif}(0, 1)$, 直接平均 X_i^2 的单样本方差为

$$\text{Var}(X^2) = \frac{1}{5} - \frac{1}{9} = \frac{4}{45}.$$

重要性采样与方差 若 $P \ll Q$, 权重 $w = dP/dQ$, 则

$$I = \mathbb{E}_Q[w(X)f(X)].$$

从 Q 采样得到无偏估计

$$\hat{I}_n^{\text{IS}} = \frac{1}{n} \sum_{i=1}^n w(X_i)f(X_i), \quad X_1, \dots, X_n \text{ 独立同分布于 } Q. \quad (10.29)$$

无偏性只要求乘积可积; 有限方差还要求 $\mathbb{E}_Q[w^2 f^2] < \infty$ 。

对上述积分, 取 Q 的密度 $q(x) = 2x$, 而 P 为均匀分布。除零测点 $x = 0$ 外, $w(x) = 1/(2x)$, 于是 $w(x)f(x) = x/2$ 。单样本方差变为

$$\mathbb{E}_Q \left[\frac{X^2}{4} \right] - \frac{1}{9} = \frac{1}{8} - \frac{1}{9} = \frac{1}{72},$$

小于直接平均的 $4/45$ 。这次改进来自 Q 把更多样本放到 x^2 贡献较大的区域。并非任意改变分布都会降低方差; 若 Q 在重要区域过轻, 权重尾部反而会放大误差。

这个例子背后有一个理想基准。对固定的被积函数 f , 无偏改写其实不要求整个 $P \ll Q$, 只要求 Q 支配有符号测度 $f dP$: 若 $Q(A) = 0$, 则

$\int_A |f| dP = 0$ 。当 P, Q 相对于同一测度分别有密度 p, q 时, 这等价于 $q(x) > 0$ 在 $|f(x)|p(x) > 0$ 处几乎处处成立。此时令

$$h_Q(x) = \frac{f(x)p(x)}{q(x)}, \quad q(x) > 0,$$

便有 $I = \mathbb{E}_Q[h_Q(X)]$ 。若 $0 < \mathbb{E}_P|f(X)| < \infty$, 则在满足这一支配条件的提议密度中, 使 $\mathbb{E}_Q[h_Q^2]$ 最小的选择满足

$$q^*(x) = \frac{|f(x)|p(x)}{\mathbb{E}_P|f(X)|}.$$

它把采样质量直接放到被积函数绝对贡献大的区域。若 $f(x) = 0$ 而 $p(x) > 0$, 则 $q^*(x) = 0$, 所以一般并没有 $P \ll Q^*$, 密度比 p/q^* 也不必在该点定义; 但该点对 $f dP$ 没有贡献, 而且不会被 Q^* 采到, 只需把 h_{Q^*} 定义到 Q^* -几乎处处即可。特别地, 当 $f \geq 0$ 时, $q^* = fp/I$, 且 $h_{Q^*}(X) = I$ 在 Q^* 下几乎处处成立, 理论方差为零。

这个分布通常不能直接执行: 归一化常数就是未知积分 I , 而从 fp/I 精确采样也可能与原问题一样困难。若还要用同一组权重估计其他被积函数, 因而必须保留 $P \ll Q$, 可以取 $q_\eta = (1-\eta)q^* + \eta p$, 其中 $0 < \eta < 1$; 混入的 p 为所有 P -正质量区域保留严格正支持。理想分布因此只提供设计直觉; 实际提议分布还必须能够归一化、采样并计算密度, 同时覆盖 $|f|p$ 非零的区域。

控制变量与相关性 若 $f(X)$ 的波动与另一个量 $h(X)$ 一起变化, 而且 $h(X)$ 的均值已知, 就可以用 $h(X)$ 偏离均值的部分抵消 $f(X)$ 的波动。令辅助变量的均值为 μ_h , 对任意 β ,

$$f_\beta(X) = f(X) - \beta(h(X) - \mu_h)$$

仍有期望 I 。其方差为

$$\text{Var}(f_\beta) = \text{Var}(f) - 2\beta \text{Cov}(f, h) + \beta^2 \text{Var}(h).$$

当 $\text{Var}(h) > 0$ 时, 最优系数为

$$\beta^* = \frac{\text{Cov}(f, h)}{\text{Var}(h)}.$$

对 $f(X) = X^2$, $h(X) = X$ 与均匀 X , 有 $\mu_h = 1/2$ 且 $\beta^* = 1$ 。调整后的变量

$$X^2 - X + \frac{1}{2}$$

仍以 $1/3$ 为均值, 方差降为 $1/180$ 。实际用同一批数据估计 β^* 时, 有限样本无偏性和方差公式需要重新核对; 把估计系数当成固定常数会忽略额外随机性。

Rao-Blackwell 化与方差分解 设 Y 是目标 I 的无偏估计, $\mathbb{E}[Y^2] < \infty$ 。对某个统计量 T 定义

$$Y^* = \mathbb{E}[Y | T].$$

全期望公式给出 $\mathbb{E}Y^* = I$, 全方差公式给出

$$\text{Var}(Y) = \mathbb{E}[\text{Var}(Y | T)] + \text{Var}(Y^*) \geq \text{Var}(Y^*). \quad (10.30)$$

这就是 Rao-Blackwell 化: 在保持均值的同时, 对已知信息求条件平均, 消去条件内噪声。

仍以 $I = 1/3$ 为例。独立生成 $X, U \sim \text{Unif}(0, 1)$, 令

$$Y = \mathbb{I}\{U \leq X^2\}.$$

则 $\mathbb{E}Y = 1/3$, 而 $\mathbb{E}[Y | X] = X^2$ 。因此直接平均 X^2 可以看成命中估计 Y 关于 X 的 Rao-Blackwell 化, 方差从 $(1/3)(2/3) = 2/9$ 降为 $4/45$ 。

自归一化权重与比值估计 有时能计算目标密度的形状, 却不知道使它积分为 1 的常数。设 $P \ll Q$, 已知权重只等于目标密度比乘以某个未知常数 $c > 0$, 即

$$\tilde{w}(x) = c \frac{dP}{dQ}(x),$$

在 Q -几乎处处意义下成立。对独立同分布样本 $X_i \sim Q$, 在分母为正时使用 $\tilde{w}_i = \tilde{w}(X_i)$ 并定义

$$\hat{f}_n^{\text{SN}} = \frac{\sum_{i=1}^n \tilde{w}_i f(X_i)}{\sum_{i=1}^n \tilde{w}_i}. \quad (10.31)$$

它是两个随机平均的比值, 通常在有限样本下有偏, 因为一般而言 $\mathbb{E}[A/B] \neq \mathbb{E}A/\mathbb{E}B$ 。一致性的证明及矩条件留到第 10.4.3.3 节。若 $\tilde{w}$ 不是目标密度比的公共常数倍, 归一化权重便描述另一个加权分布, 不能据此声称估计的是 $\mathbb{E}_P f$ 。

一个三点分布可以同时看清方差、截断与重采样的不同作用。令支持集为 $\{a, b, c\}$, 提议分布和目标分布分别为

$$Q = (0.8, 0.15, 0.05), \quad P = (0.4, 0.3, 0.3),$$

于是重要性权重为 $w = (0.5, 2, 6)$ 。对 $f = (0, 1, 1)$, 目标均值为 $I = 0.6$ 。原始单样本贡献 $Z = wf = (0, 2, 6)$ 满足

$$\mathbb{E}_Q Z = 0.6, \quad \text{Var}_Q(Z) = \{0.15 \times 4 + 0.05 \times 36\} - 0.6^2 = 2.04.$$

因此 n 个独立样本的无偏估计方差为 $2.04/n$ 。若把权重截断在 2, 则 $w^{(2)} = (0.5, 2, 2)$, 相应贡献的期望变为 0.4, 方差变为

$$\{0.15 \times 4 + 0.05 \times 4\} - 0.4^2 = 0.64.$$

截断降低了方差, 却引入 -0.2 的偏差; 两者必须同时报告。

再看一组包含二十个采样点的样本, 这些点也称为粒子; 其中恰好有 16 个 a 、3 个 b 和 1 个 c 。原始权重总和为 20, 归一化后的三点质量恰为 $(0.4, 0.3, 0.3)$ 。按这些质量做 20 次多项重采样, 三点后代数的条件期望为 $(8, 6, 6)$; 重采样后无权平均的条件期望仍为 0.6, 但条件方差增加了

$$\frac{0.6(1 - 0.6)}{20} = 0.012.$$

若先截断, 归一化质量变成 $(0.5, 0.375, 0.125)$, 重采样均值的条件期望是 0.5, 不会恢复被截断改变的目标。原始和截断权重在这组粒子上的经验有效样本量分别约为 $400/52 = 7.69$ 与 $256/20 = 12.8$: 较均匀的权重提高了这一诊断量, 但不证明偏差消失。

经验有效样本量常写成

$$\hat{n}_{\text{eff}} = \frac{(\sum_i \tilde{w}_i)^2}{\sum_i \tilde{w}_i^2}.$$

它反映权重是否集中在少数采样点上, 但不能当作对所有估计目标都成立的精确独立样本数。截断权重可降低方差, 却通常引入偏差; 重采样减少后续计算中的权重不均, 却增加额外随机性。本节的“自归一化”是随机比值估计, 第 10.4.5.3 节的自归一化集中则用随机设计矩阵度量累计噪声, 二者对象不同。

10.4.3 随机序列的收敛

“越来越接近”可能说的是几乎每条实现, 也可能只是大误差事件越来越少, 或分布整体趋近。这些含义不能互换。先规定接近方式, 再讨论平均和缩放波动各自趋向什么。

10.4.3.1 随机结果的收敛方式

逐个时刻的尾概率还不足以判断一条样本路径是否反复进入坏事件。记

$$\limsup_{n \rightarrow \infty} A_n = \bigcap_{m=1}^{\infty} \bigcup_{n \geq m} A_n,$$

它表示事件 A_n 发生无穷多次。

定理 10.46 Borel-Cantelli 引理 对事件序列 $(A_n)_{n \geq 1}$, 有以下两条结论。

1. 若 $\sum_{n=1}^{\infty} \mathbb{P}(A_n) < \infty$, 则 $\mathbb{P}(\limsup_n A_n) = 0$; 这一方向不要求独立。
2. 若事件 $A_1, A_2, \dots$ 相互独立, 且其概率之和发散, 即

$$\sum_{n=1}^{\infty} \mathbb{P}(A_n) = \infty,$$

则 $\mathbb{P}(\limsup_n A_n) = 1$ 。

证明. 对第一条, 联合界给出

$$\mathbb{P}\left(\bigcup_{n \geq m} A_n\right) \leq \sum_{n \geq m} \mathbb{P}(A_n) \rightarrow 0.$$

而 $\limsup_n A_n$ 包含在每个尾并集中, 故其概率为零。对第二条, 固定 m 。独立性给出

$$\mathbb{P}\left(\bigcap_{n=m}^N A_n^c\right) = \prod_{n=m}^N \{1 - \mathbb{P}(A_n)\} \leq \exp\left\{-\sum_{n=m}^N \mathbb{P}(A_n)\right\} \rightarrow 0.$$

因此从任意 m 开始至少有一个 A_n 发生的概率都为一; 再对可数个 m 取交, 便得到 A_n 几乎必然发生无穷多次。 ■

随机收敛的四种方式

定义 10.47 随机变量的收敛 以下依概率、几乎必然和 L^p 收敛要求 X_n, X 定义在同一概率空间上; 依分布收敛只要求它们的分布有定义。若对每个 $\varepsilon > 0$,

$$\mathbb{P}(|X_n - X| > \varepsilon) \rightarrow 0,$$

就称 X_n 依概率收敛到 X , 记作 $X_n \rightarrow_{\mathbb{P}} X$ 。它允许小概率坏事件随 n 改变, 只要求每个固定容差外的概率趋于零。

若

$$\mathbb{P}\left(\lim_{n \rightarrow \infty} X_n = X\right) = 1,$$

就称 X_n 几乎必然收敛到 X , 记作 $X_n \rightarrow_{\text{a.s.}} X$ 。它要求除一个固定零测集外, 每条样本路径最终都收敛, 因而比依概率收敛更强。

对 $1 \leq p < \infty$, 若 $X_n, X \in L^p(\mathbb{P})$ 且 $\mathbb{E}[|X_n - X|^p] \rightarrow 0$, 就称 X_n 在 L^p 中收敛。特别地, $p = 2$ 称为均方收敛。Markov 不等式给出

$$\mathbb{P}(|X_n - X| > \varepsilon) \leq \frac{\mathbb{E}[|X_n - X|^p]}{\varepsilon^p},$$

所以 L^p 收敛蕴含依概率收敛。

若对 X 的每个分布函数连续点 x , 都有

$$F_{X_n}(x) \rightarrow F_X(x),$$

就称 X_n 依分布收敛到 X , 记作 $X_n \Rightarrow X$ 。它只比较边缘分布, 不要求变量定义在同一概率空间上。

主要蕴含关系为

$$X_n \rightarrow_{\text{a.s.}} X \implies X_n \rightarrow_{\mathbb{P}} X \implies X_n \Rightarrow X,$$

以及 L^p 收敛蕴含依概率收敛。前两个蕴含可以直接证明。若 $X_n \rightarrow_{\text{a.s.}} X$, 则对固定 $\varepsilon > 0$, 指示变量 $\mathbb{I}\{|X_n - X| > \varepsilon\}$ 几乎处处趋于 0, 并由常数 1 控制。支配收敛定理给出

$$\mathbb{P}(|X_n - X| > \varepsilon) = \mathbb{E}\mathbb{I}\{|X_n - X| > \varepsilon\} \rightarrow 0.$$

若 $X_n \rightarrow_{\mathbb{P}} X$, 对 F_X 的连续点 x 和任意 $\varepsilon > 0$, 事件包含关系给出

$$F_X(x - \varepsilon) - \mathbb{P}(|X_n - X| > \varepsilon) \leq F_{X_n}(x) \leq F_X(x + \varepsilon) + \mathbb{P}(|X_n - X| > \varepsilon).$$

先令 $n \rightarrow \infty$, 再令 $\varepsilon \downarrow 0$, 由 F_X 在 x 处连续便得 $F_{X_n}(x) \rightarrow F_X(x)$ 。

定理 10.48 Lévy 连续性定理 令 X_n 的特征函数为 $\varphi_n(t) = \mathbb{E}[e^{itX_n}]$ 。若 $\varphi_n(t)$ 对每个 $t \in \mathbb{R}$ 收敛到函数 $\varphi(t)$, 且 φ 在 $t = 0$ 处连续, 则 φ 是某个概率分布的特征函数; 若 X 服从该分布, 则 $X_n \Rightarrow X$ 。反过来, 若 $X_n \Rightarrow X$, 则 $\varphi_n(t) \rightarrow \varphi_X(t)$ 对每个 t 成立。

该定理允许先证明特征函数在每个参数点收敛, 再据此推出随机变量依分布收敛。“极限在零点连续”不能省略; 它排除极限质量逃向无穷远而不再对应概率分布的情形。

前面几种收敛方式之间的蕴含关系, 一般不能反过来使用。下面先说明: 依概率收敛不一定推出均方收敛。令 $U \sim \text{Unif}(0, 1)$, 并取

$$X_n = \sqrt{n}\mathbb{I}\{U \leq 1/n\}.$$

则 $X_n \rightarrow 0$ 几乎必然且依概率成立, 但 $\mathbb{E}[X_n^2] = 1$, 所以不均方收敛。另一方面, 可以安排概率为 $1/n$ 的独立事件 A_n , 令 $Y_n = \mathbb{I}_{A_n}$ 。此时 $Y_n \rightarrow_{\mathbb{P}} 0$, 但 $\sum_n \mathbb{P}(A_n) = \infty$, 定理 10.46 的第二条说明 A_n 几乎必然发生无穷多次, 故 Y_n 不几乎必然收敛到零。

依分布收敛到常数时可以推出依概率收敛到该常数; 依分布收敛到非退化随机变量则通常不能。若 X 关于原点对称, 令 $X_n = -X$, 则 X_n 与 X 同分布, 却不必有 $|X_n - X| \rightarrow 0$ 。

虽然依概率收敛不保证整列逐路径收敛, 却允许从每条子列中找到逐路径收敛的进一步子列。这正是下面把概率控制转为积分控制所需的工具。

引理 10.49 依概率收敛的子列判据 对同一概率空间中的度量空间值随机变量, $X_n \rightarrow_{\mathbb{P}} X$ 当且仅当每条子列都有进一步子列几乎必然收敛到 X 。

证明. 若依概率收敛, 在任意子列中递归选取指标 n_k , 使 $\mathbb{P}\{d(X_{n_k}, X) > 2^{-k}\} \leq 2^{-k}$ 。Borel–Cantelli 引理使这些偏差事件几乎必然只发生有限次, 故所选子列逐路径趋于 X 。反之, 若不依概率收敛, 则存在 $\varepsilon, \eta > 0$ 及一条子列, 其每项都满足 $\mathbb{P}\{d(X_{n_k}, X) > \varepsilon\} \geq \eta$ 。它不可能有几乎必然趋于 X 的进一步子列, 否则对偏差指示函数使用支配收敛, 概率将趋于零。 ■

只控制大多数结果上的误差, 还不能交换极限与期望: 极少数结果可以贡献固定的平均质量。下面的条件直接限制这种尾部贡献。

定义 10.50 一致可积 可积随机变量族 $\{X_n\}$ 若满足

$$\lim_{K \rightarrow \infty} \sup_n \mathbb{E}[|X_n| \mathbb{I}\{|X_n| > K\}] = 0,$$

就称为一致可积 (uniformly integrable)。

它排除了这样的情况: 极端取值出现的概率越来越小, 却仍对绝对值的期望贡献一个不消失的量。若 $X_n \rightarrow_{\mathbb{P}} X$ 且 $\{X_n\}$ 一致可积, 先由一致尾界得到 $\sup_n \mathbb{E}|X_n| < \infty$ 。选一个几乎必然收敛的子列, 再用 Fatou 引理, 便有 $X \in L^1$ 。令 $T_K(x) = \max\{-K, \min\{x, K\}\}$, 把误差拆成

$$\begin{aligned} \mathbb{E}|X_n - X| &\leq \mathbb{E}|X_n - T_K(X_n)| \\ &\quad + \mathbb{E}|T_K(X_n) - T_K(X)| \\ &\quad + \mathbb{E}|T_K(X) - X|. \end{aligned}$$

第一项由一致可积性随 K 增大而统一趋零, 第三项由 X 可积趋零。固定 K 后, 从任意子列用引理 10.49 抽取几乎必然收敛的进一步子列; 截断函

数连续且中间差值不超过 $2K$ ，故支配收敛使中项在该子列上趋零。若整列中项不趋零，就能选出始终大于某个正数的子列，与上述结论矛盾。因此先令 $n \rightarrow \infty$ 、再令 $K \rightarrow \infty$ ，得到 $\mathbb{E}|X_n - X| \rightarrow 0$ 。没有一致可积性，例如 $V_n = n\mathbb{I}\{U \leq 1/n\}$ 虽几乎必然趋于 0，却满足 $\mathbb{E}V_n = 1$ ，小概率上的大幅值会阻止期望收敛。

图 10.5 把这个反例画在同一个基础结果 U 上。尖峰变高时，其底宽按相同比例缩小；每条曲线下的面积仍是 1。对任何固定 K ，只要 $n > K$ ，全部面积都位于 $V_n > K$ 的尾部，因此一致可积定义中的 $\sup_n$ 不能趋于零。这里失败的是对整个变量族的统一尾部控制，而不是每条样本路径的收敛。渐近展开经常同时出现确定的缩放因子和随机余项。不能用“每次取值都




图 10.5 小概率尖峰对期望的贡献（解析式教学图）。左图为 $V_n(u) = n\mathbb{I}\{u \leq 1/n\}$ 在 $n = 4, 16$ 时的取值，均以面积 1 贡献期望；右图对 $n \geq 2$ 显示 $\mathbb{P}(V_n > 1) = 1/n$ 趋于零，而 $\mathbb{E}V_n = 1$ 不变。基础变量为 $U \sim \text{Unif}(0, 1)$ 。

有限”代替余项控制：所需的是坏事件的概率能被同一常数压小。概率阶记号把这种控制与确定数列的阶区分开。

定义 10.51 概率阶记号 概率有界 (bounded in probability) 把“随机量不会随 n 逃向无穷”写成精确的概率条件。若对每个 $\epsilon > 0$ ，都存在有限常数 M 和整数 n_0 ，使

$$\sup_{n \geq n_0} \mathbb{P}(|X_n| > M) < \epsilon,$$

就记 $X_n = O_{\mathbb{P}}(1)$ 。若 $X_n \rightarrow_{\mathbb{P}} 0$ ，则记 $X_n = o_{\mathbb{P}}(1)$ 。对确定正数列 a_n ，约定 $X_n = O_{\mathbb{P}}(a_n)$ 与 $X_n = o_{\mathbb{P}}(a_n)$ 分别表示 $X_n/a_n = O_{\mathbb{P}}(1)$ 与 $X_n/a_n = o_{\mathbb{P}}(1)$ 。

依分布收敛的序列必然概率有界，但 $O_{\mathbb{P}}(1)$ 本身不指定唯一极限分布。

定理 10.52 连续映射 若 $X_n \rightarrow X$ 几乎必然或依概率, 且可测函数 g 在 X 的取值处几乎必然连续, 则 $g(X_n) \rightarrow g(X)$ 具有相应收敛方式。若 $X_n \Rightarrow X$ 且 $\mathbb{P}(X \in D_g) = 0$, 其中 D_g 为 g 的不连续点集, 则 $g(X_n) \Rightarrow g(X)$ 。变量可取值于 Polish 空间。

证明. 几乎必然情形逐条在连续点应用确定序列的极限规则。依概率情形使用子列判据: 每个子列都有一个几乎必然收敛的子子列, 应用前一结论, 再用同一判据返回依概率收敛。依分布情形对闭集 C , 有 $\overline{g^{-1}(C)} \subseteq g^{-1}(C) \cup D_g$; 下一小节 Portmanteau 的闭集上界给出 $\limsup_n \mathbb{P}(g(X_n) \in C) \leq \mathbb{P}(g(X) \in C)$, 即得结论。■

例如倒数映射在零不连续; 只有极限以概率一非零时才可直接取倒数。均方收敛不能对任意连续函数自动传递, 因为变换可能放大尾部。

定理 10.53 Slutsky 定理 若 $X_n \xrightarrow{d} X$, 且 $Y_n \xrightarrow{\mathbb{P}} c$, 其中 c 为常数, 则

$$X_n + Y_n \xrightarrow{d} X + c, \quad X_n Y_n \xrightarrow{d} cX.$$

若 $c \neq 0$, 还有 $X_n/Y_n \xrightarrow{d} X/c$ 。特别地, 若 $R_n = o_{\mathbb{P}}(1)$, 则 $X_n + R_n \xrightarrow{d} X$ 。

Slutsky 定理允许把收敛到常数的标准误、归一化因子或余项代入渐近分布。它不表示两个一般随机极限可以忽略联合分布; 关键条件是其中一个序列依概率收敛到常数。

定理 10.54 Delta 方法 若 $\sqrt{n}(\hat{\theta}_n - \theta) \xrightarrow{d} \mathcal{N}(0, V)$, 且 g 在 θ 处可微, 则

$$\sqrt{n}(g(\hat{\theta}_n) - g(\theta)) \xrightarrow{d} \mathcal{N}(0, g'(\theta)^2 V).$$

证明. 记

$$Z_n = \sqrt{n}(\hat{\theta}_n - \theta), \quad Z \sim \mathcal{N}(0, V).$$

先补出证明所需的两条概率阶规则。由 $Z_n \xrightarrow{d} Z$, 对任意 $\epsilon > 0$, 可取充分大的 M 使 $\mathbb{P}(|Z| \geq M) < \epsilon/2$ 。依分布收敛的闭集上界给出

$$\limsup_{n \rightarrow \infty} \mathbb{P}(|Z_n| \geq M) \leq \mathbb{P}(|Z| \geq M) < \epsilon/2,$$

所以 $Z_n = O_{\mathbb{P}}(1)$ 。此外, 若 $A_n = o_{\mathbb{P}}(1)$, $B_n = O_{\mathbb{P}}(1)$, 则对任意 $\eta, \epsilon > 0$, 先取 M 使大样本下 $\mathbb{P}(|B_n| > M) < \epsilon/2$, 再取充分大的 n 使 $\mathbb{P}(|A_n| > \eta/M) < \epsilon/2$ 。于是

$$\mathbb{P}(|A_n B_n| > \eta) \leq \mathbb{P}(|B_n| > M) + \mathbb{P}(|A_n| > \eta/M) < \epsilon,$$

即 $o_{\mathbb{P}}(1)O_{\mathbb{P}}(1) = o_{\mathbb{P}}(1)$ 。

特别地, $\hat{\theta}_n - \theta = n^{-1/2}Z_n = o_{\mathbb{P}}(1)$, 所以估计量依概率一致。Taylor 展开给出

$$g(\hat{\theta}_n) - g(\theta) = g'(\theta)(\hat{\theta}_n - \theta) + r_n(\hat{\theta}_n - \theta),$$

其中一致性与可微性保证 $r_n = o_{\mathbb{P}}(1)$ 。乘以 $\sqrt{n}$ 后, 余项是 $r_n Z_n = o_{\mathbb{P}}(1)$ 。主项由假设依分布收敛, 再用 Slutsky 定理即得结论。■

例如若某估计量满足 $\sqrt{n}(\hat{\theta}_n - \theta) \Rightarrow \mathcal{N}(0, \sigma^2)$, 且 $\theta > 0$, 取 $g(\theta) = \log \theta$, 其渐近方差为 σ^2/θ^2 。估计量以趋于一的概率落在正半轴; 在非正事件上任取一个约定值不影响极限。若 $g'(\theta) = 0$, 一阶 Delta 方法仍成立, 但只给出零方差的退化极限; 要描述非退化波动, 需要更高阶展开与新的缩放。若 g 在目标点不可微, 才不能直接应用上述定理。

10.4.3.2 概率分布的弱收敛

此前的依分布收敛比较数值随机结果。路径、随机向量和最优传输中的联合分布也需要同一种比较, 但未必共用基础概率空间。此时直接比较概率测度, 比寻找逐点对应更自然。

定义 10.55 概率测度的弱收敛 对同一度量空间上的 Borel 概率测度 P_n, P , 若对每个有界连续实函数 h 均有 $\int h dP_n \rightarrow \int h dP$, 就称 P_n 弱收敛到 P , 记作 $P_n \Rightarrow P$ 。这种概率测度的弱收敛 (weak convergence of probability measures) 只比较各测度的积分, 不要求随机变量在同一基础空间上逐点接近。

有界连续函数是比较分布的探针: 连续性不放大微小位置移动, 有界性不让极少量远处质量主导结果。实数上的这个定义等价于在 F 的全部连续点上有 $F_n(x) \rightarrow F(x)$, 也就与随机变量的依分布收敛一致。例如 $\delta_{1/n} \Rightarrow \delta_0$, 但对集合 $\{0\}$, 前者始终赋概率零、后者赋概率一; 弱收敛不要求每个事件的概率都收敛。

定理 10.56 Portmanteau 的常用形式 在 Polish 空间 E 上, Borel 概率测度 $P_n \Rightarrow P$ 等价于下列任一条件: 对每个闭集 C , $\limsup_n P_n(C) \leq P(C)$; 对每个开集 G , $\liminf_n P_n(G) \geq P(G)$; 对每个满足 $P(\partial A) = 0$ 的 Borel 集 A , $P_n(A) \rightarrow P(A)$ 。弱收敛还给出每个非负下半连续函数 c 的积分下界

$$\int c dP \leq \liminf_n \int c dP_n.$$

这里 Polish 指拓扑可由完备可分度量诱导。闭集条件可由连续函数 $h_k(x) = \max\{1 - k d(x, C), 0\}$ 从上逼近 $\mathbb{1}_C$ 得到, 开集条件再取补集。若边

界质量为零，对内部和闭包夹逼即得事件概率收敛。非负下半连续函数可由递增的有界连续函数逼近，先对每个逼近函数取弱极限，再用单调收敛，得到积分不等式。这也解释了为何非负成本的极限只能先得到下界；无界一般函数需要额外的尾部控制。

弱收敛的另一困难是质量可能不断远移，使任何候选极限都留不住总概率。需要紧性把绝大部分质量统一留在可控区域。

定义 10.57 紧概率测度与一致紧族 度量空间上的 Borel 概率测度 P 称为紧的，若对每个 $\varepsilon > 0$ 存在紧集 K ，使 $P(K^c) < \varepsilon$ 。一族概率测度 $\mathcal{P}$ 称为一致紧的，若对每个 $\varepsilon > 0$ 可取同一个紧集，使 $\sup_{Q \in \mathcal{P}} Q(K^c) < \varepsilon$ 。

定理 10.58 Prokhorov 定理 Polish 空间上的 Borel 概率测度族一致紧，当且仅当它相对弱序列紧，即每个序列都能抽出弱收敛到该空间上某个概率测度的子列。每个单独的 Borel 概率测度都是紧的。

定理保证可抽取子列，不保证所有子列具有同一极限；还需识别极限才能证明整列收敛。单个测度紧也不等于一个族一致紧。例如 $\{\delta_n : n \geq 1\}$ 的每个成员都紧，但任何固定紧集只能留住有限多个点，整个族不一致紧。

在 $\mathbb{R}^d$ 中，若 $\sup_n \mathbb{E}\|X_n\|^p \leq C < \infty$ ，其中 $p > 0$ ，则

$$\sup_n \mathbb{P}(\|X_n\| > R) \leq C/R^p.$$

闭球紧，故这些分布一致紧。在一般无限维空间，闭有界集未必紧，单有范数矩界不能照搬此论证。后面路径收敛还需控制短时间内的振荡；“随机分布”章的第 11.4.2.1 节则在固定边缘下构造共同紧集。二者都使用本节的通用定义，不是固定测度下的积分交换。

10.4.3.3 聚合结果的极限规律

定理 10.59 强大数定律 若 $X_1, X_2, \dots$ 独立同分布，且 $\mathbb{E}[|X_1|] < \infty$ ，则

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i \rightarrow_{\text{a.s.}} \mathbb{E}[X_1].$$

强大数定律说明同一分布下的独立重复观测，其平均几乎必然接近期望。有限方差是许多初等证明使用的方便条件，但独立同分布版本的结论只需有限一阶绝对矩。若观测相关、分布随时间变化或样本由自适应规则收集，则不能直接引用该定理；第 10.4.6.2 节给出相关过程的一组替代条件⁴。

⁴ O. Kallenberg, *Foundations of Modern Probability*, Springer, 2021, 3rd ed.

有限方差时, 较弱的依概率结论可以在这里完整得到。若 $\text{Var}(X_1) = \sigma^2 < \infty$, 独立性使

$$\text{Var}(\bar{X}_n) = \frac{1}{n^2} \sum_{i=1}^n \text{Var}(X_i) = \frac{\sigma^2}{n}.$$

把式 (10.19) 用于样本平均, 有

$$\mathbb{P}(|\bar{X}_n - \mathbb{E}X_1| \geq \varepsilon) \leq \frac{\sigma^2}{n\varepsilon^2} \rightarrow 0.$$

这证明了有限方差版本的弱大数定律。强大数定律只要求有限一阶绝对矩, 但其证明还需截断大取值、控制截断变量的独立和, 并把可求和坏事件转成几乎必然结论; 不能由上面的逐个 n 概率界直接推出。

对例 10.6 中的独立同分布噪声, 只要 $\mathbb{E}|\varepsilon_i| < \infty$, 便有

$$\bar{Y}_n = \theta + \frac{1}{n} \sum_{i=1}^n \varepsilon_i \rightarrow_{\text{a.s.}} \theta.$$

这回答了“多测几次再平均是否稳定”, 但没有给出固定 n 时误差超过指定阈值的概率。

中心极限定理与缩放波动

定理 10.60 Lindeberg-Lévy 中心极限定理 若 $X_1, X_2, \dots$ 独立同分布, $\mathbb{E}X_1 = \mu$, $0 < \text{Var}(X_1) = \sigma^2 < \infty$, 则

$$\frac{\sqrt{n}(\bar{X}_n - \mu)}{\sigma} \Rightarrow \mathcal{N}(0, 1).$$

大数定律研究未缩放误差是否趋于零, 中心极限定理研究乘以 $\sqrt{n}$ 后的剩余波动近似什么分布。它给出渐近近似, 而不是每个有限 n 都精确服从高斯分布。若方差无限、样本依赖过强或分布随 n 变化而不满足相应 Lindeberg 条件, $\sqrt{n}$ 缩放与高斯极限都可能失效。

证明的关键是特征函数。令 $Y_i = (X_i - \mu)/\sigma$, 并记 $\varphi(t) = \mathbb{E}e^{itY_1}$ 。复指数绝对值恒为 1, 所以特征函数总有定义。由 $\mathbb{E}Y_1 = 0$ 、 $\mathbb{E}Y_1^2 = 1$ 及零点处的二阶展开,

$$\varphi(u) = 1 - \frac{u^2}{2} + o(u^2), \quad u \rightarrow 0.$$

独立性使标准化和的特征函数分解为

$$\mathbb{E} \exp \left\{ it \frac{1}{\sqrt{n}} \sum_{i=1}^n Y_i \right\} = \left[\varphi \left(\frac{t}{\sqrt{n}} \right) \right]^n \rightarrow e^{-t^2/2}.$$

右侧是标准高斯的特征函数，并且在零点连续。定理 10.48 于是给出依分布收敛。第 10.5.4.2 节会用这个渐近分布构造近似区间，但有限样本覆盖仍需额外误差控制，不能只引用极限式。现在可以回到第 10.4.2.3 节，逐项核验积分近似的长期条件。直接平均只要 $\mathbb{E}|f(X)| < \infty$ 就强一致，若再有有限正方差，则中心极限定理给出 $\sqrt{n}(\hat{I}_n - I) \Rightarrow \mathcal{N}(0, \text{Var}(f(X)))$ 。重要性采样把 $f(X)$ 换成 $w(X)f(X)$ ，因此要在来源分布下分别查 $\mathbb{E}|wf|$ 和 $\mathbb{E}(wf)^2$ ；密度比存在并不推出第二项有限。

控制变量使用预先固定的系数及已知均值时，同样对修正后的被积量检查一阶、二阶矩。若系数由同一数据估计，无偏性可能不再成立；在系数一致、控制变量有适当矩等条件下，可用 Slutsky 分析其余项，不能直接照搬固定系数公式。Rao-Blackwell 化的条件期望保留一阶可积性，在二阶可积时又由条件 Jensen 不等式不增方差。

自归一化重要性估计是两个平均的比。设非归一化权重 $\tilde{w} \geq 0$, $0 < Z = \mathbb{E}_Q \tilde{w} < \infty$, 且 $\mathbb{E}_Q |\tilde{w}f| < \infty$ 。沿用 $\tilde{w}/Z = dP/dQ$ 及独立同分布的 Q 样本，两个强大数定律和连续映射给出

$$\frac{\sum_i \tilde{w}(X_i)f(X_i)}{\sum_i \tilde{w}(X_i)} \rightarrow \frac{\mathbb{E}_Q[\tilde{w}f]}{Z} = I \quad \text{几乎必然.}$$

分母由强大数定律最终远离零。若 $\mathbb{E}_Q[\tilde{w}^2(1+f^2)] < \infty$ ，可把中心化比值直接写成

$$\sqrt{n}(\hat{I}_{\text{SN}} - I) = \frac{n^{-1/2} \sum_{i=1}^n \tilde{w}(X_i)(f(X_i) - I)}{n^{-1} \sum_{i=1}^n \tilde{w}(X_i)}.$$

分子的求和项独立同分布，均值为零，方差为 $\mathbb{E}_Q[\tilde{w}^2(f - I)^2]$ 。方差为正时，标量中心极限定理给出分子的高斯极限；分母强收敛到 $Z > 0$ ，再用 Slutsky 定理，得到渐近方差

$$\frac{\mathbb{E}_Q[\tilde{w}^2(f - I)^2]}{Z^2}.$$

若该方差为零，分子各项几乎必然为零，极限相应退化为零常量。这没有消除有限样本比值偏差。固定阈值截断权重通常收敛到截断后的目标；若希望阈值随样本量增长而仍恢复原积分，还要证明被截去尾部和随机误差同时消失。

10.4.4 从随机序列到随机过程

序列已经能表达离散轮次；连续时间还包含不可数多个时刻。一条路径上的正则性因而不能由逐点边缘条件替代。

10.4.4.1 时间索引与样本路径

一个随机变量描述一次结果；要研究多次观测如何关联，必须把它们放到同一个概率空间上。

定义 10.61 随机过程 给定概率空间 $(\Omega, \mathcal{F}, \mathbb{P})$ 、索引集 T 和状态可测空间 $(\mathcal{X}, \mathcal{A})$ ，随机过程 (stochastic process) 是一族随机变量 $(X_t)_{t \in T}$ ，其中每个 $X_t : \Omega \rightarrow \mathcal{X}$ 均可测。

离散时间通常取 $T = \mathbb{N}_0$ ，连续时间取 $T = [0, \infty)$ 。固定时刻 t ， $\omega \mapsto X_t(\omega)$ 是随机变量；固定基础结果 ω ， $t \mapsto X_t(\omega)$ 是样本路径。所谓连续时间只规定索引可以任取实数，不规定取值连续，更不规定路径连续。

图 10.6 中，沿横轴看一条线，是一次实现随时间怎样变化；沿竖线看多个交点，是同一时刻在不同实现中的结果。右连续阶梯路径可以在连续时间定义却只取整数；连续实值路径也可能非常粗糙。稍后的 Poisson 和 Brownian 过程分别给出这两种情形的正式模型。




图 10.6 同一过程的路径与时刻截面是不同对象。图为人为给定的三条示意路径，竖虚线固定时刻 t_0 ；交点展示该时刻可能出现的不同值，并非用三条路径估计出的概率密度。

10.4.4.2 有限维分布与过程规律

给定各个有限时刻集合上的联合分布，当前要检查它们能否来自同一个过程。构造出过程以后，还要检查能否选择连续路径的版本；比较一系列近似过程时，则要检查整条路径是否收敛。这三个问题分别涉及过程的存在、路径的正则性与近似过程的极限，不能由单个时刻的分布一并回答。

只给每个时刻的边缘分布, 无法判断相邻时刻是同向、独立还是反向变化。有限维分布是在任意有限时刻集合上给出 $\mathcal{L}(X_{t_1}, \dots, X_{t_m})$, 把这种共同变化也保存下来。

要把这些有限观测放到同一个空间中, 记 E^T 为全部映射 $x: T \rightarrow E$ 的集合。其乘积 σ 代数由有限坐标柱集生成; 这类集合的形式是

$$\{x \in E^T : (x(t_1), \dots, x(t_m)) \in B\},$$

其中 B 为有限积 E^m 中的可测集。它只检查有限个坐标是否满足某项条件, 再由可数集合运算生成更多事件; 每个坐标评价 $x \mapsto x(t)$ 因此可测。

定理 10.62 Kolmogorov 扩张的标准 Borel 版本 设状态空间 E 是标准 Borel 空间, T 为任意索引集。若给定每个有限索引集合 $J \subset T$ 上的概率测度 P_J , 且对有限集合 $J \subset K$, 从 E^K 投影到 E^J 把 P_K 推送为 P_J , 则存在唯一的概率测度定义在 E^T 的乘积 σ 代数上, 使各坐标过程具有这些有限维分布。用有序时刻元组表示时, 还必须满足重排坐标的相容性。

相容性意味着同一个两时刻问题, 不论直接指定还是从三时刻问题删掉一个坐标, 都应得到同一答案。高斯过程的半正定核会提供一组相容的高斯向量, 因而可用此定理建立过程。扩张定理不同时承诺它落在连续路径空间中, 也不保证 $(t, \omega) \mapsto X_t(\omega)$ 联合可测。这里的唯一性只针对乘积 σ 代数中的事件; 整条路径的连续性还须另行建立版本及适合的路径空间。

若对每个固定 $t, \mathbb{P}(X_t = Y_t) = 1$, 称 X, Y 互为版本; 若 $\mathbb{P}(\forall t, X_t = Y_t) = 1$, 则称不可区分。不可数时间集上, 两者不同。例如 U 在 $[0, 1]$ 均匀分布, $X_t = \mathbb{1}_{\{t=U\}}, Y_t = 0$: 每个固定时刻两者几乎必然相等, 但每条 X 路径都在某个时刻出现尖点。若两个版本都具有右连续路径, 则先在可数稠密时刻同时相等, 再用右连续性推广, 才得到不可区分。

描述连续路径的粗糙程度时, 称 x 在紧时间区间上具有正指数 α 的 Hölder 连续性, 是指存在有限 C_x , 使

$$|x(t) - x(s)| \leq C_x |t - s|^\alpha \quad \text{对区间内所有 } s, t \text{ 成立.}$$

随机路径允许常数 C_x 依赖具体实现。 $\alpha = 1$ 就是 Lipschitz 条件; 在短时间差上, 较小的正指数给出较弱的约束。例如 $\sqrt{t}$ 满足 $|\sqrt{t} - \sqrt{s}| \leq |t - s|^{1/2}$, 却在零点附近不满足 Lipschitz 条件。这里是路径正则性, 与同名的 Hölder 积分不等式不同。

得到连续版本的一项常用充分条件是 Kolmogorov 连续性准则：若在紧时间区间上存在 $p > 0, \beta > 0, C < \infty$, 使

$$\mathbb{E}|X_t - X_s|^p \leq C|t - s|^{1+\beta},$$

则存在连续版本, 并可取得任意小于 β/p 的正 Hölder 指数; 该条件本身不保证达到端点 β/p 。条件控制的是整族短时增量, 不能由每个时刻分布连续推出。对 Brownian 增量, 四阶矩为 $3|t - s|^2$, 足以给出连续版本; 更高阶矩可把 Hölder 指数推进到任意小于 $1/2$ 。

10.4.4.3 随机路径的收敛条件

前面讨论同一个过程是否有连续版本; 现在比较的是一列过程及其极限。路径极限把整条函数当成随机对象, 必须先规定函数之间怎样接近。对实值连续路径, $C([0, T])$ 取一致距离 $\|x - y\|_\infty = \sup_{t \leq T} |x(t) - y(t)|$, 是 Polish 空间。对右连续且有左极限的路径, 使用 $D([0, T])$ 及 Skorokhod J_1 拓扑: 若存在严格递增的连续双射 $\lambda_n : [0, T] \rightarrow [0, T]$, 使

$$\|\lambda_n - \text{id}\|_\infty \rightarrow 0, \quad \|x_n \circ \lambda_n - x\|_\infty \rightarrow 0,$$

就有 $x_n \rightarrow x$ 于该拓扑。它允许跳跃时刻略微错开, 再对齐比较; 相应拓扑可由完备可分度量刻画。若极限连续, J_1 收敛等价于一致收敛。

有限维收敛仍不够。取确定连续函数

$$x_n(t) = \max\{1 - n^2|t - 1/n|, 0\}, \quad 0 \leq t \leq 1, n \geq 2.$$

每个固定时刻最终避开窄尖峰, 所以任意有限维向量趋零; 但 $\|x_n\|_\infty = 1$, 不可能在 $C([0, 1])$ 中趋零。越来越窄的尖峰没有被有限个截面发现, 却阻止了路径规律的紧性。

定理 10.63 连续路径的紧性与极限识别 设 X_n 是 $C([0, T])$ 值随机对象。令

$$w(x, \delta) = \sup_{\substack{s, t \in [0, T] \\ |t - s| \leq \delta}} |x(t) - x(s)|.$$

若 $(X_n(0))$ 的分布一致紧, 且对每个 $\varepsilon > 0$,

$$\lim_{\delta \downarrow 0} \sup_n \mathbb{P}\{w(X_n, \delta) > \varepsilon\} = 0,$$

则路径分布一致紧。若其有限维分布还收敛到某个连续过程 X 的有限维分布, 则 $X_n \Rightarrow X$ 于 $C([0, T])$ 。

这里用到 Arzelà–Ascoli 定理的确定性形式：紧区间上一族连续函数若统一有界且等度连续，其一致范数闭包就是紧集。等度连续指对每个误差阈值，都能选择同一个时间间隔，同时控制族内全部函数的短时变化；每个函数各自连续还不够。该紧性定理的证明见实分析教材⁵。

为把概率条件对应到这两项要求，固定 $0 < \epsilon < 1$ 。由初值一致紧选 $M < \infty$ ，使 $\sup_n \mathbb{P}(|X_n(0)| > M) \leq \epsilon/2$ 。再取 $\eta_k = 2^{-k}$ ，逐个选取递减的 $\delta_k \downarrow 0$ ，使

$$\sup_n \mathbb{P}\{w(X_n, \delta_k) > \eta_k\} \leq \epsilon 2^{-k-1}, \quad k \geq 1.$$

联合界说明每条 X_n 以至少 $1 - \epsilon$ 的概率同时满足初值界和全部尺度的振荡界。满足这些限制的确定性路径族等度连续；把 $[0, T]$ 分成有限个长度不超过 δ_1 的小段，还得到统一幅度界 $M + [T/\delta_1]\eta_1$ 。因此其闭包是承载至少 $1 - \epsilon$ 概率的紧集，得到所需路径分布的一致紧性。

Prokhorov 定理给出子列极限，坐标评价在 C 中连续，因此有限维规律识别每个子列极限。连续路径的 Borel 规律由稠密时刻坐标决定，故所有子列指向同一个极限。若连续 X_n 满足统一矩界 $\mathbb{E}|X_n(t) - X_n(s)|^p \leq C|t - s|^{1+\beta}$ ，且初值一致紧，则是上述模连续性条件的一项常用充分条件。

跳跃路径不能使用同一个连续模量：一个合法跳跃已使其无法趋零。对 D 空间须另证 J_1 紧性，再在极限几乎必然连续的時刻核对有限维收敛。例如可用有界时间内的紧包含条件及停时短增量条件建立紧性；这些是额外假设，不由单时刻收敛自动成立。

随机游走经过缩放，可以近似连续时间的随机运动。若 ξ_i 独立同分布、均值零、方差一，令 $S_k = \sum_{i=1}^k \xi_i$ ，在网格 k/n 上取 $S_k/\sqrt{n}$ 并作线性插值。Donsker 定理说明这些随机折线在 $C([0, T])$ 中弱收敛到标准 Brownian 运动。阶梯插值相应地在 D 的 J_1 拓扑收敛。这里同时需要有限维极限与路径紧性，不能只把单时刻中心极限定理改写成带 t 的公式；Brownian 的完整定义见第 10.4.6.4 节。

10.4.5 随机过程中的依赖结构

未来可以依赖历史，但要说清依赖的哪一部分。Markov 关系约束完整条件分布，鞅关系只约束条件均值，平稳性则比较时间平移前后的联合规律。共同的准备是把“已经知道什么”写成一个逐渐增加的信息族。

定义 10.64 滤过、适应与可预测性 在概率空间 $(\Omega, \mathcal{F}, \mathbb{P})$ 上，令每个 $\mathcal{F}_t$ 都是 $\mathcal{F}$ 的子 σ 代数，并且

$$\mathcal{F}_0 \subseteq \mathcal{F}_1 \subseteq \cdots \subseteq \mathcal{F}.$$

⁵ G. B. Folland, *Real Analysis: Modern Techniques and Their Applications*, Wiley, 1999, 2nd ed.

这列递增的子 σ 代数称为滤过 (filtration)，可以理解为随时间增长的信息。随机变量 X_t 若对 $\mathcal{F}_t$ 可测，就称它在时刻 t 已经可知；若每个 t 都如此，称 (X_t) 适应于该滤过。对 $t \geq 1$ ，过程 (H_t) 若 H_t 对 $\mathcal{F}_{t-1}$ 可测，就称为可预测过程 (predictable process)。

这里的“可预测”不是说 H_t 没有随机性，而是说它可以由第 t 次新噪声到来之前的信息确定。例如，设备可以在累计读数第一次超过阈值时停止测量。停止决定只使用当时已有的数据；不能先看完整段数据，再把某个有利时刻当作事先可以决定的停止点。

定义 10.65 停时 相对于滤过 $(\mathcal{F}_t)_{t \geq 0}$ ，取值于 $\mathbb{N}_0 \cup \{\infty\}$ 的随机时刻 τ 若满足 $\{\tau \leq t\} \in \mathcal{F}_t$ 对每个整数 $t \geq 0$ 成立，就称为停时 (stopping time)。

到时刻 t 为止已有的信息足以判断是否已经停止；“最后一次达到最大值的时刻”通常需要看到未来，不一定是停时。

10.4.5.1 Markov 条件分布关系

描述下一次设备状态时，完整历史可能太复杂。如果当前状态已包含预测下一步所需的全部信息，就可以用给定当前状态后的下一步分布，代替给定完整历史后的下一步分布。

定义 10.66 Markov 链 设 $(Z_t)_{t \geq 0}$ 取值于可测空间 $(\mathcal{Z}, \mathcal{A})$ 。若对每个 $B \in \mathcal{A}$,

$$\mathbb{P}(Z_{t+1} \in B \mid Z_0, \dots, Z_t) = \mathbb{P}(Z_{t+1} \in B \mid Z_t),$$

则称 (Z_t) 为 Markov 链 (Markov chain)；上述条件等式按几乎必然意义理解。

这个条件不是说过去没有影响，而是说当前状态已经保存了预测下一步所需的全部历史信息。

定义 10.67 时间齐次 Markov 链 若存在从 $(\mathcal{Z}, \mathcal{A})$ 到自身的概率核 P ，使所有 $t \geq 0$ 、 $B \in \mathcal{A}$ 都满足

$$\mathbb{P}(Z_{t+1} \in B \mid Z_t) = P(Z_t, B) \quad \text{几乎必然},$$

则该 Markov 链称为时间齐次的 (time-homogeneous)。

时间齐次描述机制不变，不代表 Z_t 的边缘分布不随时间改变⁶。

概率核的两项要求见定义 10.20: 每个状态对应合法的下一步分布, 而每个事件的概率随当前状态可测地变化。对有界可测函数 f , 记

$$Pf(z) = \int_{\mathcal{Z}} f(z')P(z, dz').$$

两个核的复合按

$$(PQ)(z, B) = \int_{\mathcal{Z}} Q(z', B)P(z, dz')$$

定义; 它表示先按 P 走一步, 再按 Q 走一步。令 $P^0(z, B) = \mathbb{I}\{z \in B\}$, $P^{m+1} = P^m P$, 则时间齐次链满足

$$\mathbb{P}(Z_{t+m} \in B \mid Z_t = z) = P^m(z, B), \quad P^{m+n}(z, B) = \int_{\mathcal{Z}} P^n(z', B)P^m(z, dz'). \quad (10.32)$$

第二个等式称为Chapman-Kolmogorov 关系。证明可直接使用条件概率的塔式性质: 给定 $Z_{t+m} = z'$ 后, Markov 性质把后 n 步的条件概率化为 $P^n(z', B)$; 再对 Z_{t+m} 在给定 $Z_t = z$ 时的分布 $P^m(z, dz')$ 积分, 就得到右侧。取 $n = 1$ 并归纳, 还同时证明了第一个等式及核幂确实给出多步转移。

定义 10.68 平稳分布 概率分布 π 若满足

$$\pi(B) = \int_{\mathcal{Z}} P(z, B) \pi(dz), \quad B \in \mathcal{A}, \quad (10.33)$$

就称为 P 的平稳分布 (stationary distribution)。

若 $Z_0 \sim \pi$, 式 (10.33) 保证每个 Z_t 仍服从 π ; 若从指定状态 z_0 启动, 平稳性本身却没有说明 $\mathcal{L}(Z_t)$ 会趋向 π 。恒等转移核 $P(z, B) = \mathbb{I}\{z \in B\}$ 保持任意分布, 但它永远不忘记初态, 这已经表明“保持目标”和“到达目标”是两项不同要求。

定义 10.69 细致平衡 概率核 P 与概率测度 π 满足细致平衡 (detailed balance), 若以下两个联合测度在 $\mathcal{Z} \times \mathcal{Z}$ 上相同:

$$\pi(dz)P(z, dz') = \pi(dz')P(z', dz). \quad (10.34)$$

它要求平稳运行时任意两处之间的概率流量正反相等。对 z 积分便得到 (10.33), 所以细致平衡足以推出平稳性。反向不成立: 围绕三个状态单向循环的链可以保持均匀分布, 却没有逐边对称的反向流。细致平衡是构造采样链时便于核验平稳性的充分条件, 而不是遍历平均成立的必要条件。换测度也可作用于整段观测, 而不只作用于一个随机变量。考虑长度 T 的轨迹 $\tau = (s_0, a_0, s_1, a_1, \dots, s_T)$, 其中 s_t 记录当前状态, a_t 记录当步行动。假定行动只按当前状态的概率核 $\pi(a_t \mid s_t)$ 产生, 下一状态只按 $P(s_{t+1} \mid s_t, a_t)$

产生，且这两个核不随时间改变。初始分布为 ρ 时，条件概率的链式分解给出

$$p_{\pi}(\tau) = \rho(s_0) \prod_{t=0}^{T-1} \pi(a_t | s_t) P(s_{t+1} | s_t, a_t).$$

若目标策略为 π ，采样策略为 μ ，并且两者共享同一初始分布和环境转移核，公共因子相消，得到

$$\frac{p_{\pi}(\tau)}{p_{\mu}(\tau)} = \prod_{t=0}^{T-1} \frac{\pi(a_t | s_t)}{\mu(a_t | s_t)}. \quad (10.35)$$

该公式要求目标轨迹分布绝对连续于采样轨迹分布。具体地说，只要 $\pi(a | s) > 0$ ，在可能到达的状态上就需要 $\mu(a | s) > 0$ 。共同环境假设若不成立，转移核的比值也必须保留。即使每一步比值有限，长轨迹连乘仍可能产生极大方差；密度比存在并不提供可用的二阶误差界。

10.4.5.2 鞅条件均值关系

在公平下注或无系统漂移的累计误差中，即使下一步波动依赖过去，给定过去后的平均增量仍应为零。鞅用这项条件均值关系描述累计过程。

定义 10.70 鞅与鞅差 可积过程 (M_t) 若适应于 $(\mathcal{F}_t)$ ，并满足

$$\mathbb{E}[M_t | \mathcal{F}_{t-1}] = M_{t-1}, \quad (10.36)$$

就称为鞅 (martingale)。增量 $X_t = M_t - M_{t-1}$ 满足

$$\mathbb{E}[X_t | \mathcal{F}_{t-1}] = 0, \quad (10.37)$$

称为鞅差 (martingale difference)。若条件等式改为 $\mathbb{E}[M_t | \mathcal{F}_{t-1}] \leq M_{t-1}$ ，称 (M_t) 为超鞅；改为 $\geq$ 时称为次鞅。两者也要求每个时刻可积且适应。

这里的 t 是离散整数时刻。连续时间的定义把相邻时刻条件换成：对任意 $0 \leq s \leq t$ ， $\mathbb{E}[M_t | \mathcal{F}_s] = M_s$ 几乎必然；每个时刻仍须可积且适应。超鞅与次鞅分别改用 $\leq$ 和 $\geq$ 。后面的补偿计数与布朗运动均使用这一连续时间版本。无条件零均值不够：若 X_t 可以由过去预测，累计和仍可能形成系统漂移；式 (10.37) 排除的正是这种可利用的条件平均。

示例 10.71 公平随机游走与按过去下注 设 ε_t 独立取 $\{-1, 1\}$, 两种取值概率均为 $1/2$, 并令 $\mathcal{F}_t = \sigma(\varepsilon_1, \dots, \varepsilon_t)$ 。公平随机游走 $S_t = \sum_{s=1}^t \varepsilon_s$ 是鞅。

现在允许下注额 H_t 根据过去结果选择, 只要求 H_t 对 $\mathcal{F}_{t-1}$ 可测, 并使 $H_t \varepsilon_t$ 可积。财富过程

$$M_t = M_0 + \sum_{s=1}^t H_s \varepsilon_s$$

仍是鞅, 因为

$$\mathbb{E}[H_t \varepsilon_t \mid \mathcal{F}_{t-1}] = H_t \mathbb{E}[\varepsilon_t \mid \mathcal{F}_{t-1}] = 0.$$

策略可以追涨、反向或在某些历史后停止下注, 但只要它不能偷看 ε_t , 就不能改变下一笔收益的条件均值。若 H_t 依赖当前尚未揭晓的 ε_t , 上面的等式便失去依据。

鞅关系约束每一步的条件均值, 但是否存在长期极限仍需条件。非负超鞅的上穿论证给出一个基本结论。设 (L_t) 为非负超鞅且 $\mathbb{E}L_0 < \infty$ 。对任意有理数 $0 < a < b$, 记 $U_n[a, b]$ 为 $L_0, \dots, L_n$ 从不高过 a 到不低于 b 的完整上穿次数。在每次不高过 a 时持有一单位过程、达到 b 时卖出; 由于 (L_t) 是超鞅, 这个可预测交易策略的期望收益不大于 0。比较每次完整交易至少 $b - a$ 的路径收益与最后一次未完成交易, 得到 Doob 上穿不等式

$$(b - a)U_n[a, b] \leq \text{交易收益} + (L_n - a)^-, \quad x^- := \max\{-x, 0\}.$$

其中负部 $(L_n - a)^-$ 至多为 a , 而交易收益的期望不大于 0。取期望得到

$$(b - a)\mathbb{E}U_n[a, b] \leq \mathbb{E}(L_n - a)^- \leq a.$$

令 $n \rightarrow \infty$ 可知每个正有理区间几乎必然只被上穿有限次。若 L_t 的下极限严格小于上极限, 就能在二者之间选到一个正有理区间并产生无穷多次上穿, 形成矛盾。因此 L_t 几乎必然存在扩展实数极限; 再由 Fatou 引理与 $\sup_t \mathbb{E}L_t \leq \mathbb{E}L_0 < \infty$ 排除极限为正无穷。于是非负超鞅几乎必然收敛到有限随机变量。这个结论只保证路径极限存在; 若还要交换极限与期望, 仍需一致可积等额外条件。非负性不是鞅收敛的唯一入口。对有正有负的累计误差, 常能控制的是二阶矩。

定理 10.72 二阶矩有界鞅的收敛 若 $(M_n, \mathcal{F}_n)$ 是平方可积鞅且 $\sup_n \mathbb{E}M_n^2 < \infty$, 则存在 $M_\infty \in L^2$, 使 $M_n \rightarrow M_\infty$ 几乎必然且在 L^2 中成立, 并且 $M_n = \mathbb{E}[M_\infty \mid \mathcal{F}_n]$ 。

证明. 对 $m \geq n$, 条件均值性质给出 $\mathbb{E}[M_n(M_m - M_n)] = 0$, 所以

$$\mathbb{E}(M_m - M_n)^2 = \mathbb{E}M_m^2 - \mathbb{E}M_n^2.$$

右侧来自单调有界数列, 故 M_n 在 L^2 中 Cauchy, 有 L^2 极限 M_∞ . 还需将均方极限提升到整条序列的几乎必然极限. 对有限鞅 Y_j 及 $Y^* = \max_{j \leq N} |Y_j|$, 按首次越过水平 a 的时刻分解事件, 并用 $|Y_j| \leq \mathbb{E}[|Y_N| | \mathcal{F}_j]$, 得

$$a \mathbb{P}(Y^* \geq a) \leq \mathbb{E}[|Y_N| \mathbb{I}_{\{Y^* \geq a\}}].$$

积分并用 Cauchy-Schwarz, 得到 $\mathbb{E}(Y^*)^2 \leq 2\mathbb{E}(|Y_N|Y^*) \leq 2\|Y_N\|_2\|Y^*\|_2$, 故 $\mathbb{E}(Y^*)^2 \leq 4\mathbb{E}Y_N^2$. 把它用于从 n 起的差鞅, 再令有限终点趋于无穷, 有

$$\mathbb{P}\left\{\sup_{m \geq n} |M_m - M_n| > \varepsilon\right\} \leq \frac{4}{\varepsilon^2}(\mathbb{E}M_\infty^2 - \mathbb{E}M_n^2).$$

取子列 n_k , 使括号小于 2^{-4k} , 并取 $\varepsilon = 2^{-k}$, 坏事件概率可求和. Borel-Cantelli 表明整列几乎必然 Cauchy, 极限与 L^2 极限一致. 最后对 $A \in \mathcal{F}_n$, 令 $m \rightarrow \infty$ 于 $\mathbb{E}[M_m \mathbb{I}_A] = \mathbb{E}[M_n \mathbb{I}_A]$, 得到所述条件期望表示. ■

随机逼近将用平方可和步长控制累计鞅噪声; 状态本身是否收敛, 还要结合稳定性与漂移, 不能只用这一定理替代.

10.4.5.3 历史条件下的累计误差

累计误差的均值为零, 还不足以说明它会波动多大. 平方可积时, 可以在每一步新结果出现前计算这一步的条件方差, 再把各步方差累加. 这个累计尺度会进入下面的集中界.

定义 10.73 可预测二次变差 对平方可积鞅差, 定义可预测二次变差 (predictable quadratic variation)

$$V_t = \sum_{s=1}^t \mathbb{E}[X_s^2 | \mathcal{F}_{s-1}]. \quad (10.38)$$

它在每一步使用新增量到来之前可知的条件方差, 因而能够记录实际噪声规模. 与之不同, $\sum_{s=1}^t X_s^2$ 是观察后的实现二次变差. Freedman 界使用前; 在其他序贯估计中也可以围绕后者构造界, 但不能不加说明地互换.

固定时刻的误差界 若只知道每个鞅差的范围, 可以把独立变量的指数矩方法逐步条件化.

定理 10.74 Azuma–Hoeffding 不等式 设 $(X_t, \mathcal{F}_t)_{t=1}^n$ 为鞅差, 并且几乎必然有 $a_t \leq X_t \leq b_t$, 其中 a_t, b_t 为确定常数。令 $S_n = \sum_{t=1}^n X_t$ 。则对任意 $x > 0$,

$$\mathbb{P}(S_n \geq x) \leq \exp \left\{ -\frac{2x^2}{\sum_{t=1}^n (b_t - a_t)^2} \right\}. \quad (10.39)$$

证明. 条件 Hoeffding 引理给出, 对任意 $\lambda > 0$,

$$\mathbb{E}[\exp(\lambda X_t) \mid \mathcal{F}_{t-1}] \leq \exp \left\{ \frac{\lambda^2 (b_t - a_t)^2}{8} \right\}.$$

从 $t = n$ 开始反复使用塔式性质, 得到

$$\mathbb{E} \exp(\lambda S_n) \leq \exp \left\{ \frac{\lambda^2}{8} \sum_{t=1}^n (b_t - a_t)^2 \right\}.$$

Markov 不等式于是给出

$$\mathbb{P}(S_n \geq x) \leq \exp \left\{ -\lambda x + \frac{\lambda^2}{8} \sum_{t=1}^n (b_t - a_t)^2 \right\}.$$

对 λ 优化, 取 $\lambda = 4x / \sum_{t=1}^n (b_t - a_t)^2$, 便得到式 (10.39)。 ■

这个证明没有要求 X_t 彼此独立, 只要求给定过去后均值为零, 并且条件范围受控。它根据每一步最大的可能波动计算上界, 未使用实际条件方差; 下一段先把这个条件化方法用于数据函数, 随后用 Freedman 界处理较小的实际方差。现在证明此前用于数据函数的 McDiarmid 界。设独立输入 $X_1, \dots, X_n$, 可测可积函数 f 在只改第 i 个坐标时满足 $|f(x) - f(x')| \leq c_i$ 。令

$$Z_i = \mathbb{E}[f(X_1, \dots, X_n) \mid X_1, \dots, X_i], \quad Z_0 = \mathbb{E}f, \quad D_i = Z_i - Z_{i-1}.$$

这是逐步揭示输入的 Doob 鞅, 且 $Z_n - Z_0 = f - \mathbb{E}f$ 。固定已经揭示的 $x_1, \dots, x_{i-1}$, 把尚未揭示的输入积分掉, 得到关于 x_i 的函数 $g_i(x_i)$ 。独立性保证这次积分使用同一未来分布, 所以 $|g_i(x_i) - g_i(x'_i)| \leq c_i$ 。因此给定历史后, D_i 落在长度至多 c_i 的区间中, 并且条件均值为零。区间端点可以随历史变化, 长度上界 c_i 则是事先固定的。条件 Hoeffding 引理给出

$$\mathbb{E}[e^{\lambda D_i} \mid \mathcal{F}_{i-1}] \leq e^{\lambda^2 c_i^2 / 8}.$$

逐步取条件期望后, $\mathbb{E}e^{\lambda(f-\mathbb{E}f)} \leq e^{\lambda^2 \sum_i c_i^2/8}$ 。Chernoff 优化取 $\lambda = 4u/\sum_i c_i^2$, 得到

$$\mathbb{P}(f - \mathbb{E}f \geq u) \leq \exp\left\{-\frac{2u^2}{\sum_i c_i^2}\right\}.$$

对 $-f$ 同样处理即得双侧界。若输入依赖, 更改当前输入可能同时改变未来条件分布, 上面的同一分布积分便不再成立; 不能只检查 f 的坐标差分就套用结论。

任意时刻的同时误差界 如果根据已经观察到的结果决定何时停止, 最终值就取在一个随机时刻。先要弄清: 在怎样的停止条件下, 鞅原有的期望关系仍能保留?

定理 10.75 有界停时的可选停止 设 $(M_t, \mathcal{F}_t)$ 为可积鞅, τ 为满足 $\tau \leq n$ 几乎必然成立的停时。则

$$\mathbb{E}[M_\tau] = \mathbb{E}[M_0].$$

证明. 写 $X_t = M_t - M_{t-1}$ 。由于 τ 为停时, 事件 $\{\tau \geq t\} = \{\tau \leq t-1\}^c$ 属于 $\mathcal{F}_{t-1}$, 故其指示函数是可预测的。又因为 $\tau \leq n$,

$$M_\tau = M_0 + \sum_{t=1}^n \mathbb{I}\{\tau \geq t\} X_t.$$

对每一项使用塔式性质与鞅差条件,

$$\mathbb{E}[\mathbb{I}\{\tau \geq t\} X_t] = \mathbb{E}[\mathbb{I}\{\tau \geq t\} \mathbb{E}[X_t | \mathcal{F}_{t-1}]] = 0.$$

有限求和后即得结论。 ■

定理的证明清楚标出了有界性用途: 它把随机长度的和改写为固定的有限和。无界停时需要额外条件, 例如鞅一致可积、停止后的变量由某个可积变量控制, 或增量有界且 $\mathbb{E}\tau < \infty$ 。这些条件不能省略。对从 0 开始的公平随机游走, 令 $\tau = \inf\{t : S_t = 1\}$ 。该停时几乎必然有限, 却有 $S_\tau = 1$, 所以 $\mathbb{E}S_\tau = 1 \neq 0$; 这里 $\mathbb{E}\tau = \infty$, 不能套用有界停时定理。

这两个首达性质可以在有限区间中核对。令 σ_m 为游走首次到达 1 或 $-m$ 的时刻。从任一内部位置出发, 接下来 $m+1$ 步连续向右的概率为 $2^{-(m+1)}$, 且这会使游走离开区间。因此按长度 $m+1$ 分块, 未退出的概率有几何上界, 保证 $\mathbb{E}\sigma_m < \infty$ 。从位置 j 开始, 记到达右端的概率为 p_j 、退出时间期望为 e_j 。按第一步条件化,

$$p_j = \frac{1}{2}(p_{j-1} + p_{j+1}), \quad e_j = 1 + \frac{1}{2}(e_{j-1} + e_{j+1}),$$

边界为 $p_{-m} = 0, p_1 = 1, e_{-m} = e_1 = 0$ 。解这两个有限差分方程得到

$$p_j = \frac{j+m}{m+1}, \quad e_j = (j+m)(1-j).$$

故 $\mathbb{P}_0(S_{\sigma_m} = 1) = m/(m+1)$, 令 $m \rightarrow \infty$ 便知 $\mathbb{P}_0(\tau < \infty) = 1$ 。另一方面, $\sigma_m \leq \tau$, 所以 $\mathbb{E}_0 \tau \geq \mathbb{E}_0 \sigma_m = m$ 对每个 m 成立, 期望只能为无穷。尽管无界停止未必保留期望等式, 非负超鞅仍能给出任意时刻的越界概率控制。Ville 不等式说明: 若 L_t 为非负超鞅且 $\mathbb{E}L_0 \leq 1$, 则对 $0 < \delta < 1$,

$$\mathbb{P}\left(\sup_{t \geq 0} L_t \geq \frac{1}{\delta}\right) \leq \delta. \quad (10.40)$$

在上述有界停止证明中, 把鞅差的条件均值零换为非正, 便得到超鞅版本 $\mathbb{E}L_{\tau \wedge n} \leq \mathbb{E}L_0 \leq 1$ 。固定 $0 < a' < a = 1/\delta$, 令 τ 为首次满足 $L_t \geq a'$ 的时刻。非负性给出 $a' \mathbb{P}(\tau \leq n) \leq \mathbb{E}L_{\tau \wedge n} \leq 1$; 令 $n \rightarrow \infty$, 可知某时刻实际达到 a' 的概率不超过 $1/a'$ 。事件 $\{\sup_t L_t \geq a\}$ 包含在每个较低阈值 a' 的越界事件中, 再令 $a' \uparrow a$, 即得式 (10.40)。这样也涵盖上确界只被逼近、未在某个时刻取到的情形。反演这类同时有效的检验, 可以得到随时间更新的置信集合。

定理 10.76 标量 Freedman 不等式 设 $(X_t, \mathcal{F}_t)_{t \geq 1}$ 为鞅差, 且 $|X_t| \leq b$ 几乎必然成立。令

$$S_t = \sum_{s=1}^t X_s, \quad V_t = \sum_{s=1}^t \mathbb{E}[X_s^2 | \mathcal{F}_{s-1}].$$

则对任意 $x, v > 0$,

$$\mathbb{P}(\exists t \geq 1 : S_t \geq x, V_t \leq v) \leq \exp\left\{-\frac{x^2}{2(v + bx/3)}\right\}. \quad (10.41)$$

证明. 对 $0 < \lambda < 3/b$, 标量不等式

$$e^{\lambda u} \leq 1 + \lambda u + \frac{\lambda^2 u^2}{2(1 - \lambda b/3)}, \quad |u| \leq b,$$

与 $\mathbb{E}[X_t | \mathcal{F}_{t-1}] = 0$ 共同给出

$$\mathbb{E}[e^{\lambda X_t} | \mathcal{F}_{t-1}] \leq \exp\{\psi(\lambda) \mathbb{E}[X_t^2 | \mathcal{F}_{t-1}]\}, \quad \psi(\lambda) = \frac{\lambda^2}{2(1 - \lambda b/3)}.$$

因此

$$L_t(\lambda) = \exp\{\lambda S_t - \psi(\lambda) V_t\}, \quad L_0(\lambda) = 1,$$

是非负超鞅。

令

$$\tau = \inf\{t \geq 1 : S_t \geq x, V_t \leq v\}.$$

对任意整数 n , $\tau \wedge n$ 有界。对非负超鞅应用有界停时论证, $\mathbb{E}L_{\tau \wedge n}(\lambda) \leq 1$ 。在事件 $\{\tau \leq n\}$ 上,

$$L_\tau(\lambda) \geq \exp\{\lambda x - \psi(\lambda)v\}.$$

故

$$\mathbb{P}(\tau \leq n) \leq \exp\{-\lambda x + \psi(\lambda)v\}.$$

令 $n \rightarrow \infty$, 再取 $\lambda = x/(v + bx/3)$; 该值位于 $(0, 3/b)$, 代入后得到式 (10.41)。 ■

若 $X_1, \dots, X_n$ 相互独立、中心化且 $|X_t| \leq b$, 并且 $\sum_{t=1}^n \text{Var}(X_t) \leq v$, 则自然滤过下的 X_t 构成鞅差, 且 $V_n \leq v$ 确定成立。在式 (10.41) 中固定 $t = n$ 便得到

$$\mathbb{P}(S_n \geq x) \leq \exp\left\{-\frac{x^2}{2(v + bx/3)}\right\}.$$

这正是式 (10.21) 的同常数单侧 Bernstein 型界。因此, Freedman 界把独立变量的方差敏感界推广到了条件方差随历史变化的序贯情形。

Freedman 界同时控制所有可能时刻, 但事件中还限定了 $V_t \leq v$ 。若希望得到随观测方差自动变化的单一边界, 可以把 V_t 的可能范围分成几何区间, 对各区间使用不同 v 并分配失败概率; 更精细的方法直接混合不同 λ 。无论采用哪种构造, 序贯有效性都来自非负超鞅, 而不是把固定时刻界中的 n 替换为随机停时。标量累计和只记录一个数, 但线性观测的误差还要区分方向: 测量第一个参数, 不能自动提高第二个参数的精度。第 t 次查询带有特征 $\mathbf{x}_t \in \mathbb{R}^d$, 观测为

$$y_t = \langle \mathbf{x}_t, \boldsymbol{\theta}^* \rangle + \eta_t. \quad (10.42)$$

允许 $\mathbf{x}_t$ 根据 $\mathcal{F}_{t-1}$ 中的历史结果选择, 但要求它在 η_t 揭晓前已经确定, 也就是 $\mathbf{x}_t$ 可预测; 噪声 η_t 对 $\mathcal{F}_t$ 可测。

定义 10.77 条件次高斯噪声 对 $\mathcal{F}_t$ -可测实随机变量 η_t , 若某个 $R > 0$ 使下面的条件指数矩界对每个 $\gamma \in \mathbb{R}$ 几乎必然成立, 则称其相对于过去信息 $\mathcal{F}_{t-1}$ 为参数 R^2 的条件次高斯噪声:

$$\mathbb{E}[\exp(\gamma \eta_t) \mid \mathcal{F}_{t-1}] \leq \exp\left(\frac{\gamma^2 R^2}{2}\right), \quad \gamma \in \mathbb{R}, \quad (10.43)$$

该条件蕴含可积性和给定过去后均值为零, 并且尾部由尺度 R 控制。

后面还要把确定参数 γ 换成过去可测的随机参数, 这一步需要可测逼近. 若 Γ 只取有限个有理值且对 $\mathcal{F}_{t-1}$ 可测, 在各取值事件上应用式 (10.43), 得到

$$\mathbb{E}[e^{\Gamma\eta_t - R^2\Gamma^2/2} | \mathcal{F}_{t-1}] \leq 1.$$

对任意有限实值的 $\mathcal{F}_{t-1}$ -可测 Γ , 取有理值简单函数 $\Gamma_k \rightarrow \Gamma$ 逐点逼近. 对每个 $A \in \mathcal{F}_{t-1}$, 非负 Fatou 引理给出

$$\mathbb{E}[\mathbb{I}_A e^{\Gamma\eta_t - R^2\Gamma^2/2}] \leq \liminf_k \mathbb{E}[\mathbb{I}_A e^{\Gamma_k\eta_t - R^2\Gamma_k^2/2}] \leq \mathbb{P}(A).$$

这就验证了同一条件期望界仍成立, 且避免对不可数多个参数的零测例外集取并。

累计噪声和正则化设计矩阵分别记为

$$\mathbf{S}_t = \sum_{s=1}^t \mathbf{x}_s \eta_s, \quad \mathbf{V}_t = \mathbf{V}_0 + \sum_{s=1}^t \mathbf{x}_s \mathbf{x}_s^\top, \quad \mathbf{V}_0 \succ \mathbf{0}. \quad (10.44)$$

若各增量满足 $\mathbb{E}\|\mathbf{x}_t \eta_t\|_2 < \infty$, 可预测性与条件中心化共同保证

$$\mathbb{E}[\mathbf{x}_t \eta_t | \mathcal{F}_{t-1}] = \mathbf{x}_t \mathbb{E}[\eta_t | \mathcal{F}_{t-1}] = \mathbf{0}.$$

这时 $(\mathbf{S}_t)$ 是向量鞅. 特征可预测不自动保证这一可积性; 下面的指数超鞅论证只需其条件指数矩控制, 因此自归一化界不要求额外假定整个向量和可积. 这里没有要求 $\mathbf{x}_t$ 为确定向量, 也没有要求不同 $\mathbf{x}_t$ 彼此独立; 关键是它在当前噪声出现前已经由过去确定。

某个方向被反复观测时, $\mathbf{V}_t$ 沿该方向增大; 从未被询问的方向只剩初始正则化. 因此, 自然误差尺度不是统一的欧氏球, 而是

$$\|\mathbf{S}_t\|_{\mathbf{V}_t^{-1}} = \sqrt{\mathbf{S}_t^\top \mathbf{V}_t^{-1} \mathbf{S}_t}.$$

设计提供的信息越多, 逆矩阵在相应方向上的权重越小. 这种由随机设计自身归一化误差的形式, 称为自归一化 (self-normalized); 它与第 10.4.2.3 节中用随机权重和归一化分母构造的自归一化重要性估计不是同一个对象。

混合指数超鞅与向量集中

定理 10.78 向量自归一化集中界 在式 (10.42) 至 (10.44) 的条件下, 对任意 $\delta \in (0, 1)$, 以至少 $1 - \delta$ 的概率, 对所有 $t \geq 0$ 同时有

$$\|\mathbf{S}_t\|_{\mathbf{V}_t^{-1}} \leq R \sqrt{2 \log \left(\frac{\det(\mathbf{V}_t)^{1/2}}{\det(\mathbf{V}_0)^{1/2} \delta} \right)}. \quad (10.45)$$

证明. 固定任意 $\mathbf{u} \in \mathbb{R}^d$. 由于 $\mathbf{x}_t$ 对 $\mathcal{F}_{t-1}$ 可测, 在式 (10.43) 中取 $\gamma = \langle \mathbf{u}, \mathbf{x}_t \rangle$, 得到

$$\mathbb{E} \left[\exp \left\{ \langle \mathbf{u}, \mathbf{x}_t \rangle \eta_t - \frac{R^2}{2} \langle \mathbf{u}, \mathbf{x}_t \rangle^2 \right\} \middle| \mathcal{F}_{t-1} \right] \leq 1.$$

逐步相乘可知

$$L_t(\mathbf{u}) = \exp \left\{ \langle \mathbf{u}, \mathbf{S}_t \rangle - \frac{R^2}{2} \|\mathbf{u}\|_{\mathbf{V}_t - \mathbf{V}_0}^2 \right\}$$

是非负超鞅。

一个固定 $\mathbf{u}$ 只能控制一个投影方向。为同时处理所有方向, 取独立于数据的随机向量 $\mathbf{U} \sim \mathcal{N}(\mathbf{0}, R^{-2} \mathbf{V}_0^{-1})$, 并对 $L_t(\mathbf{U})$ 关于 $\mathbf{U}$ 积分。非负性允许交换条件期望与积分, 所以混合过程 $\bar{L}_t = \mathbb{E}_{\mathbf{U}} L_t(\mathbf{U})$ 仍是非负超鞅, 且 $\bar{L}_0 = 1$ 。把高斯密度与指数中的二次项合并, 配方得到

$$\bar{L}_t = \left(\frac{\det(\mathbf{V}_0)}{\det(\mathbf{V}_t)} \right)^{1/2} \exp \left\{ \frac{1}{2R^2} \|\mathbf{S}_t\|_{\mathbf{V}_t^{-1}}^2 \right\}.$$

这里行列式比来自两个高斯二次型的归一化常数, 而指数项来自配方后的中心移动。

对 $\bar{L}_t$ 使用式 (10.40), 以至少 $1 - \delta$ 的概率, 对所有 t 都有 $\bar{L}_t < 1/\delta$ 。取对数并整理, 便得到式 (10.45)。 ■

证明中的假设和行列式因子分别解决了不同问题。条件次高斯性用于构造每一步指数超鞅; 特征可预测性允许在条件期望中把 $\mathbf{x}_t$ 视为已知; $\mathbf{V}_0 > \mathbf{0}$ 使高斯混合与逆矩阵从 $t = 0$ 起有定义; 行列式比累计各方向相对于初始尺度增长了多少。行列式不是把每个访问次数简单相加, 因为同一方向的重复观测与新方向的首次观测提供的信息不同。

10.4.5.4 时间平移下的平稳关系

“平稳分布”约束一个核如何保持一个分布; 过程的平稳性还要约束多个时刻的联合分布。一个设备长期运行时, 除了问下一步怎样依赖当前状态, 还可以问: 把观察窗口向后移动, 整段读数的联合规律是否保持不变? 这就是平稳性关心的问题。

定义 10.79 平稳过程 离散时间过程 $(Z_t)_{t \geq 0}$ 称为平稳过程 (stationary process), 若任意正整数 m 、时刻 $t_1, \dots, t_m \geq 0$ 及整数 $h \geq 0$ 都满足

$$(Z_{t_1}, \dots, Z_{t_m}) \stackrel{d}{=} (Z_{t_1+h}, \dots, Z_{t_m+h}).$$

对时间齐次 Markov 链, 若 $Z_0 \sim \pi$ 且 $\pi P = \pi$, 则

$$\mathbb{P}(Z_0 \in dz_0, \dots, Z_m \in dz_m) = \pi(dz_0) \prod_{j=1}^m P(z_{j-1}, dz_j).$$

把起点向后平移一格时, 先对 z_0 积分, $\pi P = \pi$ 把 Z_1 的边缘重新化为 π , 其余转移核不变; 反复应用便证明所有有限维分布都不随平移改变。因此, 从平稳分布启动的时间齐次链是平稳过程。只知道某一个时刻的边缘分布等于 π , 却没有核不变或联合分布条件时, 不能据此断言整个过程平稳。

定义 10.80 二阶平稳 实值过程二阶矩有限, 若均值与时间无关, 且 $\text{Cov}(X_s, X_t)$ 只依赖时间差 $t-s$, 称为二阶平稳 (second-order stationarity), 也称弱平稳。

严格平稳加有限二阶矩推出二阶平稳; 反向一般不成立。例如相互独立的序列在偶数时刻取标准高斯分布, 在奇数时刻等概率取 ± 1 。均值均为零, 方差均为一, 非同时刻协方差均为零, 所以二阶平稳, 但一维边缘随奇偶变化, 并不严格平稳。联合高斯过程则由均值与协方差完全决定有限维规律, 因此此时二阶平稳足以推出严格平稳。Brownian 运动和零均值随机游走可以是 Markov 鞅, 但方差随时间增长, 不是平稳过程; 其增量却可平稳。核的不变分布、从任意初态趋向它, 以及过程已经从该分布启动, 仍是三项不同命题。

10.4.6 典型随机过程

前面的关系不是互斥分类。同一个过程可以同时具有 Markov 性和鞅性, 也可能只有平稳增量而本身不平稳。以下例子用明确的生成规律逐项核对这些差别。

10.4.6.1 随机游走

给定独立同分布增量 ξ_i , 定义 $S_0 = 0, S_n = \sum_{i=1}^n \xi_i$, 称为随机游走 (random walk)。若 $\mathbb{E}\xi_i = \mu, \text{Var}(\xi_i) = \sigma^2 < \infty$, 则

$$\mathbb{E}S_n = n\mu, \quad \text{Var}(S_n) = n\sigma^2, \quad \text{Cov}(S_m, S_n) = \min(m, n)\sigma^2.$$

尽管增量独立, 位置之间却不独立, 因为后一个位置包含前一个位置的累计增量。 $S_n - n\mu$ 相对于增量的自然滤过是鞅, S_n 本身还具有 Markov 性。若 $\mathbb{P}(\xi_i = 1) = p, \mathbb{P}(\xi_i = -1) = 1 - p$, 则漂移为 $2p - 1$ 、单步方差为 $4p(1-p)$ 。取 $p = 0.6$, 十步均值为 2、方差为 9.6; 某一条十步路径却不必靠近均值。大数定律控制 S_n/n , 中心极限定理控制 $(S_n - n\mu)/(\sigma\sqrt{n})$; 整个折线在缩放下的极限则使用第 10.4.4.3 节的路径定理。

10.4.6.2 Markov 链

Markov 核只规定下一步怎样转移。要算若干步后的分布，就要反复组合转移核；要证明忘记初态或用长期平均估计期望，还要检查状态之间能否相互到达，以及返回需要多长时间。

状态转移与多步分布

示例 10.81 相关的两状态观测 令 $Z_t \in \{0, 2\}$ ，并把观测直接取为 $Y_t = Z_t$ 。转移矩阵按状态 0, 2 排序为

$$P = \begin{pmatrix} 0.9 & 0.1 \\ 0.2 & 0.8 \end{pmatrix}.$$

平稳分布为 $\pi = (2/3, 1/3)^\top$ ，因为 $P^\top \pi = \pi$ 。长期均值因此是

$$\mu = \mathbb{E}_\pi[Y] = \frac{2}{3}.$$

两条跨状态概率流都等于 $(2/3) \times 0.1 = (1/3) \times 0.2 = 1/15$ ，故该链还满足细致平衡。从状态 0 启动时， Y_0 不服从 π ；转移规则时间齐次，过程却要经过一段时间才接近平稳。

上面的两状态链能在两个状态之间往返，也允许留在原状态。一般链却可能困在某个状态集合中，或只能按固定节奏返回原状态。前一种障碍对应不可约性，后一种由周期描述。检查不可约性，是为了排除链被困在真子集中的可能。

定义 10.82 有限链的不可约性与周期 有限状态 Markov 链满足不可约性 (irreducibility)，若对任意状态 i, j 存在整数 $m \geq 0$ ，使 $P^m(i, \{j\}) > 0$ 。若返回步数集合非空，状态 i 的周期 (period) 定义为

$$d_i = \gcd\{m \geq 1 : P^m(i, \{i\}) > 0\}.$$

不可约链的全部状态具有共同周期；该周期为 1 时，称链为非周期的 (aperiodic)。

把相互可达的状态归在一起，得到互达等价类；若从一个类内出发，一步转移不会离开该类，就称它封闭。不可约性要求所有状态属于同一个互达类，并在有限状态下保证平稳分布唯一。

在前面的两状态例子中，令 $q_t = \mathbb{P}(Y_t = 2)$ 。一步转移给出

$$q_{t+1} = 0.1(1 - q_t) + 0.8q_t = 0.1 + 0.7q_t, \quad q_t = \frac{1}{3} + 0.7^t \left(q_0 - \frac{1}{3} \right).$$

从 $q_0 = 0$ 出发, 前两步为 $q_1 = 0.1, q_2 = 0.17$, 而不是立即得到 $1/3$ 。不变分布给出递推的不动点; 这里的收敛则由偏差系数 0.7 另行证明。

长期分布与遍历平均 更具体地, 状态 i 到 j 可达, 是指存在 $m \geq 0$ 使 $P^m(i, \{j\}) > 0$ 。令 $T_i^+ = \inf\{t \geq 1 : Z_t = i\}$; 若 $\mathbb{P}_i(T_i^+ < \infty) = 1$, 就称 i 为常返状态 (recurrent state)。有限多个互达类之间不可能沿可达关系循环而仍属于不同的类, 因此沿可达关系前进, 总能到达一个封闭类。在有限不可约链中, 还能得到比概率一返回更强的界: 固定 i , 从每个状态选一条正概率、正长度的路径到 i 。由于状态数有限, 存在统一的整数 M 与 $\varepsilon > 0$, 使从任意状态在接下来 M 步内访问 i 的概率至少为 ε 。按长度 M 的时间块使用 Markov 性质, 得到

$$\mathbb{P}_i(T_i^+ > kM) \leq (1 - \varepsilon)^k, \quad \mathbb{E}_i T_i^+ \leq M/\varepsilon < \infty.$$

所以所有状态常返, 且平均返回时间有限。对一般有限链的每个封闭类, 在类内应用相同论证, 也说明它是常返类。

从 i 出发, 把从一次访问 i 起、到下一次返回 i 前为止的路径作为一个游程。返回时刻只由已经观察到的历史决定, 属于定义 10.65 中的停时。Markov 性质在这类随机时刻之后仍成立, 称为强 Markov 性; 在有限离散链中, 把返回时刻的各个可能取值分别代入 Markov 条件即可验证。因此这些游程独立同分布。记第 k 个游程的长度为 L_k 、其中访问 j 的次数为 R_k 。已证 $\mathbb{E}_i L_1 < \infty$, 又有 $0 \leq R_k \leq L_k$, 故可对两组变量使用强大数定律:

$$\frac{\sum_{k=1}^m R_k}{\sum_{k=1}^m L_k} \longrightarrow \frac{\mathbb{E}_i R_1}{\mathbb{E}_i L_1} \quad \text{几乎必然成立。}$$

长期时间占比来自多个游程的累计比值, 而不是单次随机比值 R_k/L_k 。为识别右侧极限, 记 $a_j = \mathbb{E}_i \sum_{t=0}^{L_1-1} \mathbb{I}\{Z_t = j\}$ 。对每个 t , 事件 $\{t < L_1\}$ 属于 $\mathcal{F}_t$; 逐项条件化并使用非负换序, 得

$$\begin{aligned} \sum_{\ell} a_{\ell} \mathbf{P}_{\ell, j} &= \mathbb{E}_i \sum_{t=0}^{L_1-1} \mathbf{P}_{Z_t, j} \\ &= \mathbb{E}_i \sum_{t=0}^{L_1-1} \mathbb{I}\{Z_{t+1} = j\} = a_j. \end{aligned}$$

最后一步把计数区间从 $0, \dots, L_1 - 1$ 移到 $1, \dots, L_1$; 因游程首尾都为 i , 总计数不变。又有 $\sum_j a_j = \mathbb{E}_i L_1$, 所以归一化向量 $a_j/\mathbb{E}_i L_1$ 满足平稳方程, 由唯一性就是 π_j 。取 $j = i$ 时每个游程恰计一次访问, 因而 $\pi_i = 1/\mathbb{E}_i T_i^+$ 。

以上比值只覆盖完整游程, 还须控制任意时刻剩下的一段。令 $A_m = \sum_{k=1}^m L_k$, 强大数定律给出 $A_m/m \rightarrow \mathbb{E}_i L_1$, 相减即得 $L_m/m = A_m/m - A_{m-1}/m \rightarrow 0$ 。对 $A_m \leq n < A_{m+1}$, 未完成游程至多贡献 L_{m+1} 次访问, 而

$L_{m+1}/A_m \rightarrow 0$, 因此它不改变时间占比的极限。从任意其他初态出发, 到首次访问 i 的时间也由上述几何尾界控制; 这段有限初始路径除以 n 后趋零。由此才得到对每个整数 n 及任意初态成立的遍历平均。

矩阵方面, $\mathbf{P}^\top$ 的特征值 1 对应唯一的概率右特征向量 $\boldsymbol{\pi}$; 等价地, $\boldsymbol{\pi}^\top$ 是行随机转移矩阵 $\mathbf{P}$ 的唯一概率左特征向量。加入非周期性后, 其他模态不会在单位圆上持续振荡, 矩阵幂 $\mathbf{P}^t$ 才逐行趋于 $\boldsymbol{\pi}^\top$ 。这两条路线分别解释了为什么周期不妨碍时间占比, 却会妨碍逐时刻分布收敛。

有限、不可约、非周期链满足

$$\mathbf{P}^t(\mathbf{z}, \cdot) \longrightarrow \boldsymbol{\pi}(\cdot) \quad \text{对每个初始状态 } \mathbf{z}, \quad (10.46)$$

其中有限状态下的收敛可以用总变差距离 (total variation distance) 衡量。这一距离比较所有事件概率, 定义 11.12 将系统讨论它与其他分布差异的关系; 本节只使用下面的表达式: 对概率测度 ν, π , 定义

$$\|\nu - \pi\|_{\text{TV}} = \sup_{B \text{ 可测}} |\nu(B) - \pi(B)|.$$

不可约性与非周期性在这里服务于逐时刻分布收敛。时间平均的要求略有不同: 有限不可约链即使有周期, 对每个函数 $f: \mathcal{Z} \rightarrow \mathbb{R}$ 仍有

$$\frac{1}{n} \sum_{t=1}^n f(Z_t) \longrightarrow \mathbb{E}_\pi[f(Z)] \quad \text{几乎必然成立。} \quad (10.47)$$

例如在 0 与 2 之间确定性交替的链具有周期 2。从 0 出发时, Z_t 的分布在两个点之间来回切换, 不存在逐步极限; 但时间平均仍趋向 1。因此, 讨论“遍历”时必须说明结论针对逐步分布、时间平均还是其他对象。

例 10.81 中的两个状态相互可达, 又都有留在原状态的正概率, 因此该链不可约且非周期。其第二个特征值为 0.7。令 $\tilde{Y}_t = Y_t - \mu$, 直接计算可得

$$\mathbb{E}[\tilde{Y}_{t+1} | Z_t] = 0.7\tilde{Y}_t. \quad (10.48)$$

反复使用塔式性质便得到 $\mathbb{E}[\tilde{Y}_{t+k} | Z_t] = 0.7^k \tilde{Y}_t$ 。若链从平稳分布启动,

$$\text{Corr}_\pi(Y_t, Y_{t+k}) = 0.7^k. \quad (10.49)$$

这个几何衰减同时展示了“收敛到平稳”和“样本之间仍相关”: 边缘分布可以从一开始就等于 π , 相邻观测却不会因此独立。

一般状态空间的返回条件 有限链可用矩阵、路径和周期描述可达性。连续或一般状态空间中, 单点通常概率为零, “每个状态互相到达”不再是合适表述。

定义 10.83 一般状态空间的不可约性与 Harris 常返性 固定 $(\mathcal{Z}, \mathcal{A})$ 上的非零参考测度 φ 。常用的 φ 不可约性要求：对每个满足 $\varphi(B) > 0$ 的 $B \in \mathcal{A}$ 以及每个初态 $z \in \mathcal{Z}$ ，链从 z 出发都有正概率在有限时间内到达 B ；若只研究某个不可约类，就先把 $\mathcal{Z}$ 限制为该类的子集。在此基础上，Harris 常返性 (Harris recurrence) 要求这些正测度集合以概率 1 被反复访问；正 Harris 常返性 (positive Harris recurrence) 再要求存在不变概率分布。这里的反复访问要求：对每个上述 B 和每个初态 z ，以概率 1 有无穷多个 $t \geq 0$ 满足 $Z_t \in B$ 。

对 π 可积的 f ，正 Harris 常返性提供一般状态空间遍历大数定律的标准入口。

仅有“以正概率最终到达”还不足以保证 Harris 常返，因为过程仍可能以正概率逃离后永不返回。正 Harris 常返链对其唯一不变概率 π 满足式 (10.47) 的一般状态空间版本，但函数必须 π 可积；若只知道局部可积或某个初态下样本值有限，不能推出该时间平均结论。

逐时刻分布收敛还要排除周期轮转。在正 Harris 常返情形，一种等价的非周期表述是：不存在 $d \geq 2$ 个两两不交、各有正 π 概率且并集具有全 π 概率的可测集 $A_0, \dots, A_{d-1}$ ，使对 π -几乎所有 $z \in A_i$ 都有 $P(z, A_{(i+1) \bmod d}) = 1$ 。对标准 Borel 状态空间上的正 Harris 常返、非周期链，任意初态下均有 $\|P^t(z, \cdot) - \pi\|_{TV} \rightarrow 0$ 。这比遍历平均多要求了非周期性，但仍未给出统一的收敛速率⁷。

⁷ O. Kallenberg, *Foundations of Modern Probability*, Springer, 2021, 3rd ed.

定义 10.84 几何遍历性 对具有不变概率分布 π 的时间齐次链，几何遍历性 (geometric ergodicity) 要求存在共同的 $0 < r < 1$ ，使每个初态 z 都对应有限常数 $C(z)$ ，对所有整数 $t \geq 0$ 满足

$$\|P^t(z, \cdot) - \pi\|_{TV} \leq C(z)r^t.$$

它比“存在平稳分布”或“时间平均收敛”更强，常与额外矩条件一起用于中心极限定理、Poisson 方程和随机逼近中的相关噪声控制。几何遍历是方便而有力的充分条件，不是所有遍历链都必须满足的定义。

这些条件也解释了相关平均的边界。链若可约，长期平均可能由初始封闭类决定；链若只保持 π 而不能充分移动，有限预算误差可能很大；观测函数若不可积，平稳分布存在也不能定义所求均值。第 13 章会把相关观测用于均值求根式 (13.30)；这里提供的前提是长期平均确实识别目标均值，而不是把相关的 Y_t 假装成独立样本。

混合速度、自相关与有效样本量 返回条件回答相关平均有没有稳定目标，还没有给出接近目标所需的步数。**混合速度** (mixing rate) 描述链忘记初态的快慢。

定义 10.85 有限链的混合时间 对具有平稳分布 π 的有限时间齐次链，定义

$$d(t) = \sup_{z \in \mathcal{Z}} \|P^t(z, \cdot) - \pi\|_{TV},$$

对 $0 < \varepsilon < 1$ ，混合时间为 $t_{\text{mix}}(\varepsilon) = \inf\{t \in \mathbb{N}_0 : d(t) \leq \varepsilon\}$ ，空集的下确界约定为 ∞ 。

这个最坏初态指标针对分布距离；估计某个特定 f 的时间平均时，还要考察 $f(Z_t)$ 自身的自相关。

若链平稳，且观测函数具有有限正方差，记

$$\sigma_f^2 = \text{Var}_\pi(f(Z_0)), \quad 0 < \sigma_f^2 < \infty.$$

它在间隔 k 处的自相关为

$$\rho_f(k) = \text{Corr}_\pi(f(Z_0), f(Z_k)).$$

展开样本均值方差得到

$$\text{Var}\left(\frac{1}{n} \sum_{t=1}^n f(Z_t)\right) = \frac{\sigma_f^2}{n} \left[1 + 2 \sum_{k=1}^{n-1} \left(1 - \frac{k}{n}\right) \rho_f(k) \right]. \quad (10.50)$$

若 $\sum_{k \geq 1} |\rho_f(k)| < \infty$ ，括号中的量趋向

$$\tau_f = 1 + 2 \sum_{k=1}^{\infty} \rho_f(k),$$

称为积分自相关时间。它是非负的渐近方差比；在 $\tau_f > 0$ 时，用 $n_{\text{eff}} \approx n/\tau_f$ 表达 **自相关有效样本量** (autocorrelation effective sample size)，只是把该函数均值的渐近方差换算成独立样本尺度。它依赖 f ，也不同于重要性权重的有效样本量。若 $\sigma_f^2 = 0$ ，观测函数在平稳分布下为常数，无须定义相关系数；若 $\tau_f = 0$ ，则 $n \text{Var}(\bar{f}_n) \rightarrow 0$ ，不能用有限的 n/τ_f 概括其误差。

对例 10.81，式 (10.49) 给出

$$\tau_Y = 1 + 2 \sum_{k=1}^{\infty} 0.7^k = \frac{1 + 0.7}{1 - 0.7} = \frac{17}{3}.$$

因此，就估计这个均值的方差而言，长度为 n 的链约等价于 $3n/17$ 个独立观测。若自相关为负， τ_f 也可能小于 1。这里的有效样本量是按特定估计量的方差折算得到的数量，并不表示链中实际剩下了多少条记录。

图 10.7 把分布收敛与均值方差分开呈现。左图从同一确定初态出发，非周期链的状态概率逐渐接近平稳质量，周期链却一直交替；右图针对从平稳分布启动的非周期链，有限样本的方差放大可直接由自相关求和，不能把左图的初态偏差混入这条公式。




图 10.7 两状态链的解析式教学图。左图蓝线使用例 10.81 的转移矩阵，从 $Z_0 = 0$ 出发绘制 $\mathbb{P}(Z_t = 2) = (1 - 0.7^t)/3$ ；红线使用确定交替的转移矩阵。右图使用平稳初态和 $\rho_k = 0.7^k$ ，绘制 $1 + 2 \sum_{k=1}^{n-1} (1 - k/n) \rho_k$ ，其极限为 $17/3$ ，独立观测基准为 1。

10.4.6.3 泊松过程

事件到达使状态按次跳变。固定窗口内的计数可以服从 Poisson 分布，但只有规定不同窗口间的联合关系，才能得到 Poisson 过程。

事件计数与短时跳跃

定义 10.86 齐次 Poisson 过程 给定速率 $\lambda > 0$ 和滤过 $(\mathcal{F}_t)_{t \geq 0}$ ，计数过程 $(N_t)_{t \geq 0}$ 称为相对于该滤过的齐次泊松过程 (Poisson process)，若它适应于滤过， $N_0 = 0$ 几乎必然，路径几乎必然右连续、非减、取非负整数且每次跳跃为一，并满足

$$N_t - N_s \perp \mathcal{F}_s, \quad N_t - N_s \sim \text{Poisson}(\lambda(t - s)), \quad 0 \leq s < t.$$

这里的平稳性属于增量，而非 N_t 本身：计数均值随时间线性增长。对互不相交、按时间排列的区间，逐步使用独立于过去的条件，便得到增量相互独立。相对于自然滤过给出过程后，不能随意加入未来信息而仍称其增量独立于历史。

短区间 $h \downarrow 0$ 内,

$$\mathbb{P}(N_{t+h} - N_t = 0) = 1 - \lambda h + O(h^2),$$

$$\mathbb{P}(N_{t+h} - N_t = 1) = \lambda h + O(h^2),$$

$$\mathbb{P}(N_{t+h} - N_t \geq 2) = O(h^2).$$

一次跳跃的概率是一阶小量, 发生跳跃时的幅度却始终为一。令 $T_k = \inf\{t : N_t \geq k\}$ 为第 k 次到达时刻。有限 t 内 $N_t < \infty$ 几乎必然, 因而只有有限次跳跃; 这是有限活动过程。左极限 $N_{t-} = \lim_{s \uparrow t} N_s$ 记录跳跃发生前的计数, 跳跃量记为 $\Delta N_t = N_t - N_{t-}$ 。

Poisson 计数与指数等待是同一齐次到达机制的两个侧面。首次到达时间满足

$$\mathbb{P}(T_1 > t) = \mathbb{P}(N(t) = 0) = e^{-\lambda t}.$$

所以 T_1 服从速率为 λ 的指数分布; 独立平稳增量进一步使相邻到达间隔独立同分布。反过来, 用独立同分布的指数等待时间累加生成到达时刻, 所得计数过程的 $N(t)$ 服从 $\text{Poisson}(\lambda t)$ 。这里的联系依赖齐次性和独立增量, 不能由两个边缘分布的名称单独推出。更具体地, 独立增量的短区间概率给出前 k 个到达时刻在 $0 < t_1 < \dots < t_k$ 上的联合密度 $\lambda^k e^{-\lambda t_k}$ 。换成等待间隔 $E_i = T_i - T_{i-1}$, 其中 $T_0 = 0$, Jacobian 为一, 密度变成 $\prod_i \lambda e^{-\lambda e_i}$, 证明间隔独立且均为指数分布。等待 k 次到达的总时长因此是 $\text{Gamma}(k, \lambda)$, 采用前面约定的速率参数。反向从独立指数间隔构造时, $\mathbb{P}(T_k \leq t < T_{k+1}) = e^{-\lambda t} (\lambda t)^k / k!$; 无记忆性保证每个确定时刻之后的剩余等待仍指数, 从而得到独立平稳增量。

若每次到达还带来随机量 J_k , 其中 J_k 独立同分布且独立于计数过程, 则

$$C_t = \sum_{k=1}^{N_t} J_k$$

称为复合泊松过程 (compound Poisson process)。其跳跃量不必为一, 也可负; 给定 N_t 以后再求条件均值和全方差, 可得

$$\mathbb{E}C_t = \lambda t \mathbb{E}J_1, \quad \text{Var}(C_t) = \lambda t \mathbb{E}J_1^2$$

(第一式需一阶绝对矩有限, 第二式需二阶矩有限)。第二式不是 $\lambda t \text{Var}(J_1)$, 因为事件数本身也随机。这里的 Poisson 过程描述事件到达; 定义 13.23 中的 Poisson 方程描述 Markov 核下的均值校正, 它们不是同一个对象。

平均到达与补偿增量 计数每段时间平均增加 λh 。从原计数中减去这一可预测平均趋势, 得到补偿泊松过程 (compensated Poisson process)


$$\tilde{N}_t = N_t - \lambda t.$$

定理 10.87 Poisson 补偿的鞅性质 相对于定义 10.86 中的滤过, $\tilde{N}_t$ 是平方可积鞅, 且

$$\mathbb{E}[(\tilde{N}_t - \tilde{N}_s)^2 | \mathcal{F}_s] = \lambda(t - s), \quad \tilde{N}_t^2 - \lambda t \text{ 也是鞅.}$$

证明. 独立增量使给定 $\mathcal{F}_s$ 后的计数增量仍有均值及方差 $\lambda(t-s)$ 。减去均值后, 条件均值为零, 条件二阶矩就是该方差。再展开 $\tilde{N}_t^2 = (\tilde{N}_s + (\tilde{N}_t - \tilde{N}_s))^2$, 交叉项条件期望为零, 剩余新增二阶矩为 $\lambda(t-s)$, 得到最后一个鞅结论。■

补偿并未抹平跳跃。图 10.8 中, 计数在到达之间保持不变, 补偿路径则以斜率 $-\lambda$ 下降; 每个到达时刻仍向上跳一。平方跳跃累计为 $\sum_{s \leq t} (\Delta \tilde{N}_s)^2 =$



跳跃量同为 1; 补偿只加入斜率 -1 的连续漂移

图 10.8 给定三次到达时刻的教学路径, 取 $\lambda = 1$ 。蓝线为计数 N_t , 红虚线为 $\tilde{N}_t = N_t - t$; 两条路径在同一时刻跳跃且跳跃量相同。减去的是平均趋势, 不是实现中的跳跃。

N_t 是随机量; 其可预测平均累计为 λt , 不是同一个量。在有限活动区间上, 细分路径的平方增量和趋向跳跃平方和, 连续线性漂移贡献趋零, 故可记

$$[\tilde{N}]_t = N_t, \quad \langle \tilde{N} \rangle_t = \lambda t.$$

后一个量是使 $\tilde{N}_t^2 - \langle \tilde{N} \rangle_t$ 成为鞅的可预测补偿, 呼应离散可预测二次变差。对确定分割, 这个有限活动情形的路径计算可逐条进行; 连续粗糙路径的二次变差将在下一例说明。

复合情形若 $\mathbb{E}|J_1| < \infty$, 则 $C_t - \lambda t \mathbb{E}J_1$ 相对于只揭示已到达标记的自然历史是鞅。若再有 $\mathbb{E}J_1^2 < \infty$, 其平方跳跃累计为 $\sum_{k \leq N_t} J_k^2$, 可预测二阶累计为 $\lambda t \mathbb{E}J_1^2$ 。例如每次损失恒为二, 平均损失速率为 2λ , 二阶累计速率却

为 4λ 。随机积分将把在跳跃前确定的系数乘到这些补偿增量上；仅对有限步进系数而言，正交性已经给出

$$\mathbb{E} \left(\sum_i H_i (\tilde{N}_{t_{i+1}} - \tilde{N}_{t_i}) \right)^2 = \lambda \sum_i \mathbb{E} H_i^2 (t_{i+1} - t_i), \quad H_i \in L^2(\mathcal{F}_{t_i}),$$

这里使用确定分割与可预测系数。一般过程积分的定义及闭包条件见第 13 章“行动和状态”，其中第 13.4.2.1 节将把这一有限和延拓为补偿 Poisson 积分。

10.4.6.4 布朗运动

与一次一次的跳跃相对，连续波动的每段增量可越来越小，但累计波动仍然非零。布朗运动给出这种尺度的基本模型；连续路径不等于可微路径。

连续路径与增量尺度 设 $\xi_1, \xi_2, \dots$ 独立同分布， $\mathbb{E}\xi_i = 0$ 、 $\text{Var}(\xi_i) = 1$ 。步长为 Δt 时，定义随机游走增量

$$\Delta X_k = \sqrt{\Delta t} \xi_k.$$

经过 $n = t/\Delta t$ 步，

$$\text{Var} \left(\sum_{k=1}^n \Delta X_k \right) = n\Delta t = t.$$

若把增量缩放成 $\Delta t \xi_k$ ，方差会随 $\Delta t \rightarrow 0$ 趋零；若不缩放，固定时间内方差会发散。平方根尺度是让连续时间极限保留有限非零波动的尺度。

在有限方差及适当插值条件下，函数型中心极限定理把缩放随机游走连接到布朗运动 (Brownian motion)。本章不重证该一般弱收敛定理，而从极限所需的性质定义连续对象。

定义 10.88 标准布朗运动 实值过程 $(W_t)_{t \geq 0}$ 称为标准布朗运动，若它满足：

1. $W_0 = 0$ 几乎必然成立；
2. 对 $0 \leq t_0 < t_1 < \dots < t_n$ ，增量 $W_{t_i} - W_{t_{i-1}}$ 相互独立；
3. $W_t - W_s \sim \mathcal{N}(0, t-s)$ ，其中 $0 \leq s < t$ ；
4. 样本路径几乎必然连续。

当布朗运动与滤过 $(\mathcal{F}_t)_{t \geq 0}$ 共同使用时，还要求 W_t 对该滤过适应，并且对 $s < t$ ，增量 $W_t - W_s$ 独立于 $\mathcal{F}_s$ 。定义中的独立增量只比较布朗运动

自身的不同时间段；加入滤过后的条件保证积分中的“过去信息”不能预见下一段布朗增量。

由独立增量和方差公式，

$$\mathbb{E}[W_s W_t] = \min(s, t). \quad (10.51)$$

例如 $s \leq t$ 时， $W_t = W_s + (W_t - W_s)$ ，后一增量与 W_s 独立且均值为零，所以协方差为 $\mathbb{E}W_s^2 = s$ 。

布朗运动的尺度与路径正则性 对任意 $c > 0$ ，过程

$$\widetilde{W}_t = c^{-1/2} W_{ct}$$

仍是标准布朗运动。它从零出发，增量仍独立，并且

$$\widetilde{W}_t - \widetilde{W}_s \sim \mathcal{N}(0, t - s).$$

连续性也由原路径继承。因此两过程具有相同的有限维分布。这就是布朗运动的尺度规律。

相对于同一滤过， m 维标准 Brownian 运动 $\mathbf{W}_t = (W_t^{(1)}, \dots, W_t^{(m)})^\top$ 由相互独立的实值标准 Brownian 运动组成，并要求

$$\mathbf{W}_t - \mathbf{W}_s \perp \mathcal{F}_s, \quad \mathbf{W}_t - \mathbf{W}_s \sim \mathcal{N}(\mathbf{0}, (t - s)\mathbf{I}_m).$$

若以固定矩阵 $\mathbf{A}$ 混合这些分量，增量协方差变成 $(t - s)\mathbf{A}\mathbf{A}^\top$ ，不再是标准 Brownian 的单位协方差；低秩 $\mathbf{A}$ 允许退化扩散。

不可微性与二次变差 长度为 h 的增量典型尺度为 $\sqrt{h}$ ，所以差商

$$\frac{W_{t+h} - W_t}{h}$$

的标准差为 $1/\sqrt{h}$ ，随 $h \rightarrow 0$ 反而发散。严格结果表明，以概率 1，布朗运动的样本路径在所有时刻连续，同时在任何时刻都不可微。因此不能把 dW_t/dt 当作普通随机函数，再用 Riemann 积分处理。

布朗运动的二次变差 二次变差记录细分以后仍无法消失的平方波动。它与 $\text{Var}(W_t)$ 不同：方差在固定时刻跨样本求平均，二次变差沿同一条路径对时间增量求和再取极限。取 $[0, t]$ 的一系列确定分割 $0 = t_0 < \dots < t_n = t$ ，其最大区间长度趋零，并记平方增量和

$$Q_n = \sum_{i=0}^{n-1} (W_{t_{i+1}} - W_{t_i})^2.$$

定义 10.89 沿确定分割的二次变差 若连续过程沿每一列网格趋零的确定分割得到的平方增量和，在时刻 t 都依概率收敛到同一个随机变量，这个极限记为 $[X]_t$ ，称为该过程在 $[0, t]$ 上的二次变差。

以下计算证明标准布朗运动的极限为确定量 t ，并且收敛甚至在 L^2 中成立。其期望为

$$\mathbb{E}Q_n = \sum_i (t_{i+1} - t_i) = t.$$

独立高斯增量还给出

$$\text{Var}(Q_n) = 2 \sum_i (t_{i+1} - t_i)^2 \leq 2t \max_i (t_{i+1} - t_i).$$

因此网格趋零时， $Q_n \rightarrow t$ 在 L^2 中成立，进而依概率成立。这称为布朗运动在 $[0, t]$ 上的二次变差等于 t 。

普通连续可微路径的平方增量和会趋零，因为每个增量是 $O(\Delta t)$ ，平方后求和为 $O(\Delta t)$ 。布朗增量是 $O_{\mathbb{P}}(\sqrt{\Delta t})$ ，平方后恰好是 $O_{\mathbb{P}}(\Delta t)$ 。后文的 Itô 公式之所以保留二阶导数项，根源就在这个非零二次变差。

图 10.9 用同一组细网格高斯增量形成两种分割。平方和随分割改变，但细分后趋近的是 t ，而不是左图路径在时刻 t 的高低。单条教学折线只能说明计算对象，依概率收敛的保证来自刚才对任意确定分割给出的方差上界。




图 10.9 以固定随机种子构造的高斯增量教学例。左图由 4096 个独立增量 $\Delta W_i \sim \mathcal{N}(0, 1/4096)$ 累计成路径折线；右图将同一组增量分别合并为 64 和 1024 个时间区间，再累计各区间增量的平方。蓝、红阶梯线使用不同分割，灰色参考线为理论二次变差 t 。这里只绘制有限网格，不把某一条折线作为连续布朗路径或收敛证明。

平方增量会留下有限累计量, 这使普通积分的链式法则不再适用。第 13 章将用它建立随机积分与 Itô 换元。差商在固定时刻的方差发散, 是不可微的尺度提示, 不是“几乎必然所有时刻都不可微”的完整证明; 后者同时涉及不可数多个时刻, 是严格路径定理。相应地, $W_{t+h} - W_t = O_{\mathbb{P}}(\sqrt{h})$ 不是对全部实现、全部短区间成立的统一确定性上界。

对同一确定分割, 交叉二次变差使用增量乘积而非平方:

$$[X, Y]_t = \lim_{|\pi| \rightarrow 0} \sum_{[u, v] \in \pi} (X_v - X_u)(Y_v - Y_u),$$

这里按存在时的依概率极限理解。独立 Brownian 分量 $i \neq j$ 的和均值为零, 方差为 $\sum_{[u, v] \in \pi} (v - u)^2 \leq t|\pi|$, 所以 $[W^{(i)}, W^{(j)}]_t = 0$; 同一分量的计算则给出 t 。合写为 $[W^{(i)}, W^{(j)}]_t = \delta_{ij}t$ 。在二进分割上, 平方和方差界可求和, Borel–Cantelli 还给出逐个固定终点的几乎必然收敛; 对一般网格列, 这里的无条件结论是已证明的 L^2 及依概率收敛, 不把它加强成对所有分割同时逐路径成立。

10.4.6.5 高斯过程

如果未知的是整条校准曲线, 就不仅要描述某一个输入处的函数值, 还要描述不同输入处的值怎样一起变化。高斯过程用任意有限组函数值的联合高斯分布, 建立这样的随机函数模型。

定义 10.90 高斯过程 实值随机过程 $(F(x))_{x \in \mathcal{X}}$ 称为高斯过程 (Gaussian process), 若任意正整数 m 及任意 $x_1, \dots, x_m \in \mathcal{X}$ 上的向量 $(F(x_1), \dots, F(x_m))^T$ 均服从多元高斯分布, 允许协方差奇异。其均值函数和协方差函数为

$$m(x) = \mathbb{E}F(x), \quad k(x, x') = \text{Cov}(F(x), F(x')),$$

因而每个有限向量的均值为 $(m(x_i))_i$, 协方差矩阵为 $(k(x_i, x_j))_{i,j}$, 记作 $F \sim \mathcal{GP}(m, k)$ 。索引 x 不必代表时间。

协方差函数必须对称, 且对任意有限输入和实系数 c_i 满足

$$\sum_{i,j} c_i c_j k(x_i, x_j) \geq 0.$$

这正是有限协方差矩阵半正定的条件。均值与协方差因此确定高斯过程的全部有限维分布; 它们本身不自动保证样本函数连续、可微或具有 Markov 性。

例如令 A, B 是独立标准高斯变量, 定义 $F(x) = A + Bx$ 。任意有限函数值都是 (A, B) 的线性变换, 所以构成高斯过程, 且 $m(x) = 0, k(x, x') = 1 + xx'$ 。

三个以上不同输入的协方差矩阵可以奇异，因为这些随机值都由同两个随机系数决定。反过来，各点边缘高斯并不足够：若 $X \sim \mathcal{N}(0, 1)$ ，独立符号 S 等概率取 ± 1 ，则 X, SX 的边缘均为标准高斯且不相关，但 $(SX)^2 = X^2$ 使它们依赖，故不可能是联合高斯。定义中的“任意有限联合分布”不可省略。布朗运动是均值零、核 $k(s, t) = \min(s, t)$ 的高斯过程：每个有限向量都由独立高斯增量线性组合得到。这个核确实半正定，因为

$$\sum_{i,j} c_i c_j \min(t_i, t_j) = \int_0^\infty \left(\sum_i c_i \mathbb{1}_{\{u \leq t_i\}} \right)^2 du \geq 0.$$

一般给定均值和对称半正定核时，相应高斯有限维分布相容，可用第 10.4.4.2 节的扩张定理建立过程。要得到连续版本，仍须对核控制增量矩；“高斯过程”这个名称本身不承诺路径光滑。

10.5 随机变量的推断

此前给定概率规律，计算变量怎样变化；现在只有有限数据，规律本身未知。数理统计（mathematical statistics）研究怎样从这些观测推断规律并量化误差。估计要回答参数、分位数或分布是什么，预测要回答尚未观测的结果可能是什么。样本不能唯一重建基础空间上的映射，推断只针对明确的分布及其目标。

先固定比较标准。行动 a 是报告的结论，损失 $\ell(a, \tau(\theta))$ 衡量它偏离目标的代价，风险再对重复抽样取期望。估计量是抽样前的随机函数，估计值是观测后的具体数值。

定义 10.91 估计量的风险 给定模型、目标泛函 τ 和非负可测损失 ℓ ，估计量的风险（risk）是

$$R_\theta(\hat{\tau}) = \mathbb{E}_\theta[\ell(\hat{\tau}(\mathbf{Y}), \tau(\theta))].$$

它允许取 $+\infty$ ，并随未知参数 θ 变化。

10.5.1 观测制度与可识别目标

误差计算之前，要分别核对目标能否被观测分布确定，以及样本究竟如何进入数据集。模型不可识别与有限样本不够精确是不同困难。

10.5.1.1 推断目标与可识别性

此前信号和噪声的概率规律都已给定。现在若传感器的平均读数未知，就要把不同均值对应的分布列为候选，再用样本区分它们。样本均值是从数据算出的量，未知均值则属于候选分布，二者需要分开。

定义 10.92 统计模型与统计量 统计模型 (statistical model) 是一族候选分布

$$\mathcal{P} = \{P_{\vartheta} : \vartheta \in \Theta\}.$$

这些分布定义在同一个可测观测空间上, 参数 ϑ 是描述候选分布的未知索引。观测 $\mathbf{Y} = (Y_1, \dots, Y_n)$ 由其中某个分布产生, 但真实索引不可见。参数未必是一个物理常数; 它也可以是一组回归系数、一个混合比例, 或者无限维的分布函数。

统计量 (statistic) 是只依赖样本的可测函数 $T(\mathbf{Y})$ 。当统计量被设计来逼近某个未知目标 $\tau(\vartheta)$ 时, 它称为估计量 (estimator), 通常记为 $\hat{\tau}$ 。在一批已经观测的数据 $\mathbf{y}$ 上算出的 $\hat{\tau}(\mathbf{y})$ 是估计值 (estimate)。参数属于模型, 估计量在重复抽样中是随机变量, 估计值则是一次计算得到的数; 混淆三者会使“偏差”和“不确定性”失去对象。

推断目标可以有不同层次。估计 θ 是在参数空间中找一个点; 估计分布函数 $F(y)$ 是在函数空间中恢复整体规律; 预测未来观测 Y_{n+1} 则还要保留新噪声。即使都输出一个数, 它们回答的也不是同一个问题。例如 $\bar{Y}$ 可估计位置 θ , 而预测下一次读数还需要噪声尺度。一般地, 目标写成映射 $\tau : \Theta \rightarrow \mathcal{A}$, 其中 $\mathcal{A}$ 可以是标量、向量、函数或概率分布。能够只由可观察分布决定的目标也可进一步写成分布泛函。估计误差还必须配合损失 $\ell : \mathcal{A} \times \mathcal{A} \rightarrow [0, \infty]$ 解释; 向量目标的坐标平方误差、总平方误差和某个方向上的误差评价不同对象; 比较精度时必须说明所用的损失。

在有限方差位置模型 $Y_i = \theta + \varepsilon_i$ 中, 若误差独立、均值为零且方差为 σ^2 , 则

$$\mathbb{E}_{\theta}[\bar{Y}] = \theta + \frac{1}{n} \sum_{i=1}^n \mathbb{E}[\varepsilon_i] = \theta, \quad \text{Var}_{\theta}(\bar{Y}) = \frac{1}{n^2} \sum_{i=1}^n \text{Var}(\varepsilon_i) = \frac{\sigma^2}{n}.$$

无偏性来自零均值, $1/n$ 方差缩减还使用了独立性; 若误差相关, 方差中必须保留协方差项。

识别、等价模型与推断边界 增加样本之前还要问: 两种机制若产生完全相同的观测分布, 想估计的目标是否也相同? 若目标不同, 再多同类样本也无法区分它们。

定义 10.93 目标可识别性 给定统计模型 $\{P_{\vartheta} : \vartheta \in \Theta\}$ 和目标泛函 $\tau : \Theta \rightarrow \mathcal{T}$, 若对所有 $\vartheta_1, \vartheta_2 \in \Theta$ 有

$$P_{\vartheta_1} = P_{\vartheta_2} \implies \tau(\vartheta_1) = \tau(\vartheta_2),$$

就称目标 τ 在模型中是可识别的 (identifiable)。

取 $\tau(\vartheta) = \vartheta$ 时, 这一定义才退化为参数可识别。可识别性是总体分布层面的性质, 不是有限样本算法的表现。

示例 10.94 混合成分的标签交换 设观测来自二成分高斯混合

$$p(y) = \pi\phi(y; \mu_1, \sigma^2) + (1 - \pi)\phi(y; \mu_2, \sigma^2).$$

把 (π, μ_1, μ_2) 换成 $(1 - \pi, \mu_2, \mu_1)$ 不改变分布。若“第一成分”只表示编号, 参数便有两种等价表示; 添加 $\mu_1 < \mu_2$ 之类约束可以固定表示, 却没有创造新的观测信息。

另一种失败来自来源一起出错。若所有温度计都有未知共同偏移 b , 模型为 $Y_i = \theta + b + \varepsilon_i$, 观测只识别 $\theta + b$, 不能分别识别 θ 和 b 。增加同型号温度计会减小随机噪声, 却不会消除共同偏差。由此可见, “有很多数据”“目标可识别”和“目标容易准确估计”是三项不同判断。

不可识别还直接限制任何估计程序。若 $P_{\vartheta_1} = P_{\vartheta_2}$ 但 $\tau(\vartheta_1) \neq \tau(\vartheta_2)$, 取两目标值距离的三分之一为 $\epsilon > 0$ 。任何只依赖样本的估计量 $\hat{\tau}_n$ 在两种机制下具有相同分布, 因而不可能同时满足

$$\mathbb{P}_{\vartheta_j} \{ \|\hat{\tau}_n - \tau(\vartheta_j)\| < \epsilon \} \longrightarrow 1, \quad j = 1, 2.$$

因为两个半径为 ϵ 的球不相交, 同一个估计量分布不可能把趋近于一的概率同时赋给它们。这证明了: 不可识别目标不能靠增加同类样本在全部等价机制下一致恢复。

10.5.1.2 抽样方式与观测机制

统计结论必须先回答“想对谁成立”。目标总体 (target population) 是推断希望覆盖的对象、时间和条件的集合; 抽样制度 (sampling regime) 描述观测如何从这些对象产生。若样本只来自工作日的一个传感器, 模型本身不能把结论自动推广到周末或另一批设备。

独立同分布抽样把每个 Y_i 视为来自同一分布的独立重复。配对抽样则把 $(Y_{i,A}, Y_{i,B})$ 视为一个单位, 例如同一对象在两种条件下的读数。若各对之间独立, 则对内差值 $D_i = Y_{i,A} - Y_{i,B}$ 也相互独立; 同一对内的两个读数却可能相关。把两列拆成 $2n$ 个独立记录, 会忽略这种关系。分层抽样预先按群组分别抽取, 成组抽样则一次抽取整个设备、班级或用户群。两者的独立单位和加权方式不同。

条件分母、相关性与信息量 配对的收益取决于对内协方差：

$$\text{Var}(D_i) = \text{Var}(Y_{i,A}) + \text{Var}(Y_{i,B}) - 2 \text{Cov}(Y_{i,A}, Y_{i,B}).$$

正协方差会降低差值方差，负协方差则可能使配对更差；“同一对象测两次”本身并不保证精度提高。

设目标总体中群组 g 的比例为 π_g ，群组均值为 μ_g ，则总体均值为

$$\mu = \sum_g \pi_g \mu_g.$$

总体指标可能很好，却掩盖某个小群组的严重误差。若群组中有 n_g 个独立 Bernoulli 结果，样本比率 $\hat{p}_g$ 的方差为

$$\text{Var}(\hat{p}_g) = \frac{p_g(1 - p_g)}{n_g}.$$

这里把 n_g 视为固定正整数。若群组样本数 $N_g = \sum_i \mathbb{I}\{G_i = g\}$ 也是随机的，则 $\hat{p}_g$ 只在 $N_g > 0$ 时有定义，且上述方差是给定 N_g 后的条件方差；无条件误差还要考虑群组样本数的随机变化，并处理 $N_g = 0$ 的情形。一个群组的比例估计能有多精确，主要取决于该组有多少有效观测，不能只看全体样本量 n 。报告群组公平性或来源质量时，应同时报告组内样本数、抽样方式和区间，不能只排列百分比。

不同对象被抽中的机会不同时，样本平均会偏向更容易入样的对象。如果知道各类对象的入样概率，就可以给较少被抽中的对象更大权重，在以下条件下恢复总体平均。令 $S \in \{0, 1\}$ 表示一个总体对象是否入样， $\rho(Z) = \mathbb{P}(S = 1 | Z)$ ，并假设 $S \perp Y | Z$ 、 $\rho(Z) > 0$ 以及 $\mathbb{E}[|Y|/\rho(Z)] < \infty$ 。条件期望给出

$$\mathbb{E}\left[\frac{SY}{\rho(Z)}\right] = \mathbb{E}\left[\frac{\mathbb{E}[S | Y, Z]Y}{\rho(Z)}\right] = \mathbb{E}[Y].$$

这条逆概率恒等式恢复的是明确的总体平均。若某一区域 $\rho(Z) = 0$ ，或者入样在给定 Z 后仍依赖未观测的 Y ，等式便不能由现有数据推出。

记录数也不等于独立信息量。若同一来源复制一条记录十次，样本平均的显示分母增大，实际信息却没有增加。时间序列中的相邻读数可能共享漂移；群组内记录可能共享设备偏差。这类依赖应通过按群组建模、块抽样或第 10.4.6.2 节的相关过程工具处理，而不能继续套用独立样本方差。

时间抽样还会改变平均值代表的对象。若目标是一天中各个分钟采样点的平均读数，每分钟记录一次就对这些采样点赋予相同权重；若只在告警后加密采样，朴素平均就会过度代表异常时段。要进一步估计连续时间内的平均，还需说明采样点怎样代表相邻时段。一种修正方式是记录每个

时段被抽中的概率并作逆概率加权,但这要求所有目标时段都有正的入样概率。完全未覆盖的夜晚时段不能靠增大已有权重恢复。抽样日志因此也是统计数据的一部分。

抽样制度与分析单位应在看结果前确定。假设十台设备各产生一千条记录,而处理实际随机分配给设备,那么有效随机化单位是十台设备,不是一万条记录。记录内噪声可以帮助估计每台设备的均值,却不能把处理效应的独立单位扩充到一万。这个区别会同时影响标准误、置换方式和训练测试划分。

缺失、选择与可忽略性

不完整观测带来另一类问题。令 $R = 1$ 表示 Y 被观察到, X 为始终可见变量。完全随机缺失 (missing completely at random, MCAR) 要求

$$R \perp (X, Y).$$

随机缺失 (missing at random, MAR) 要求

$$R \perp Y \mid X,$$

即给定已观测协变量后,缺失概率不再依赖缺失值本身。若给定 X 后,缺失概率仍依赖未见的 Y ,就属于非随机缺失 (missing not at random, MNAR)。

多个变量可能按不同模式缺失,此时“已观测变量”随模式改变,不能用一个固定条件集概括全部 MAR 要求。

定义 10.95 观测模式与缺失机制 设完整数据为 $\mathbf{Z} = (Z_1, \dots, Z_d)$, 观测指示 $\mathbf{R} \in \{0, 1\}^d$ 。对每种模式 $\mathbf{r}$, 定义

$$O(\mathbf{r}) = \{j : r_j = 1\}, \quad M(\mathbf{r}) = \{j : r_j = 0\}.$$

实际记录为 $(\mathbf{r}, \mathbf{Z}_{O(\mathbf{r})})$ 。令 $g(\mathbf{r} \mid \mathbf{z})$ 为给定完整数据时的模式概率核。若对每种 $\mathbf{r}$ 都存在只依赖已见坐标的可测函数 $g_{\mathbf{r}}$, 使

$$g(\mathbf{r} \mid \mathbf{z}) = g_{\mathbf{r}}(\mathbf{z}_{O(\mathbf{r})})$$

对完整数据分布几乎处处成立,则称机制为 MAR。若 $g(\mathbf{r} \mid \mathbf{z})$ 对全部模式均不依赖 $\mathbf{z}$, 则为 MCAR; 若 MAR 条件失败, 则为 MNAR。

例如在二维数据中,模式 $(1, 0)$ 的出现概率可依赖 Z_1 , 却不能依赖未见的 Z_2 ; 模式 $(0, 1)$ 反过来可以依赖 Z_2 , 却不能依赖 Z_1 。这是对每种模式分别施加的条件,不能只在当前观测到的某一模式上核对。“随机缺失”也不等于“缺失标记完全随机”,后者对应更强的 MCAR。

当 $\mathbb{P}(R = 1) > 0$ 时, MCAR 下完整案例仍代表总体, 但效率降低。MAR 下可建模 $\mathbb{P}(R = 1 | X)$ 并加权, 或建模 $Y | X$ 后插补; 两者都依赖模型和正值条件。MNAR 通常不能只靠已观测数据识别, 需要机制假设、外部信息或敏感性分析。MAR 描述的是缺失概率依赖哪些变量, 并不意味着可以丢弃所有不完整记录。“缺失机制可忽略”则要指定在哪一种推断计算中省去机制项; 定义似然后, 式 (10.52) 将说明这种省略还需要哪些参数条件。数据表中的一个缺失标记本身不能证明属于哪种机制。

识别障碍在有界结果上已经出现。若 $0 \leq Y \leq 1$ 且 $\mathbb{P}(R = 0) > 0$, 观测数据只给出已见部分的 RY 与缺失指示; 把所有未见 Y 设为 0 或设为 1 会产生相同观测, 却给出不同总体均值。因此不加机制条件时只能得到

$$\mathbb{E}[RY] \leq \mathbb{E}[Y] \leq \mathbb{E}[RY] + \mathbb{P}(R = 0).$$

两个端点分别可由把全部未见结果设为 0 或 1 达到, 所以仅凭上述信息不能继续收紧。若 MAR 成立, 并令 $\pi(X) = \mathbb{P}(R = 1 | X) > 0$, 则第 10.5.1.2 节的逆概率恒等式在这里化为

$$\mathbb{E}\left[\frac{RY}{\pi(X)}\right] = \mathbb{E}[Y].$$

正值条件负责覆盖, 条件独立负责把未见结果接回已见结果; 权重很大时, 即使目标可识别, 有限样本方差仍可能很高。

示例 10.96 后续推断使用的传感器校准数据 考虑教学构造的 25 个独立传感器响应, 暂以高斯位置模型描述, 单次噪声标准差已知为 $\sigma = 2$, 样本汇总为

$$\bar{y} = 10.4, \quad \frac{1}{25} \sum_{i=1}^{25} (y_i - \bar{y})^2 = 4.$$

若另问响应如何随校准输入 x 变化, 靠近左边界 $x_0 = 0$ 的三个观测为

$$(x_i, y_i) = (0, 9), (1, 11), (3, 13),$$

在给定带宽下核权重为 1, 0.75, 0.25。后面的局部回归、Bootstrap、区间与预测复用这些输入, 只改变所报告的目标。它们是可核算的教学数值, 不是实测性能报告; 把局部输入关系加入模型时, 也不再把全部读数视为同一位置分布的重复抽取。

10.5.2 分布与分布特征的估计

报告一个均值和报告整张分布是不同输出，但不等于参数方法与非参数方法的划分。经验均值可以不预设参数族，整张高斯分布也可以由有限参数估计；似然、矩、损失和先验则是这些任务中可组合使用的构造依据。

10.5.2.1 有限维目标的估计

仍以未知平均读数为例：对同一批观测，可以比较不同均值下这些读数的概率或密度。把数据固定、只改变候选参数，得到的函数就是似然。给定观测 $\mathbf{y}$ 后，似然 (likelihood)

$$L(\vartheta; \mathbf{y}) = p_{\vartheta}(\mathbf{y})$$

相对于模型共同的参考测度定义，把数据固定，把参数看作待比较的变量。似然不是参数的概率分布；只有再指定先验并归一化后，才得到后验分布。最大似然估计选择 $\hat{\vartheta}_{\text{MLE}} \in \arg \max_{\vartheta} L(\vartheta; \mathbf{y})$ ，通常等价于最小化负对数似然⁸。

⁸ A. W. van der Vaart, *Asymptotic Statistics*, Cambridge University Press, 1998

现在可以明确前面的缺失机制可忽略性。以连续数据为例，令 p_{θ} 描述完整数据， g_{ψ} 描述缺失模式； θ 与 ψ 分别是两者的参数。若整个模型满足 MAR，固定已见模式 $\mathbf{r}$ 与坐标 $\mathbf{z}_{\text{obs}}$ 后，观测似然分解为

$$\begin{aligned} L_{\text{obs}}(\theta, \psi) &= \int p_{\theta}(\mathbf{z}_{\text{obs}}, \mathbf{z}_{\text{mis}}) g_{\psi}(\mathbf{r} | \mathbf{z}_{\text{obs}}) d\mathbf{z}_{\text{mis}} \\ &= g_{\psi}(\mathbf{r} | \mathbf{z}_{\text{obs}}) L_{\text{data}}(\theta), \\ L_{\text{data}}(\theta) &= \int p_{\theta}(\mathbf{z}_{\text{obs}}, \mathbf{z}_{\text{mis}}) d\mathbf{z}_{\text{mis}}. \end{aligned} \quad (10.52)$$

离散坐标把相应积分换成求和。若参数域是直积 $\Theta \times \Psi$ ，即两组参数可独立变化，在机制因子为正的观测上比较 θ 的似然时便可省去这个不含 θ 的因子。这里省去的是机制模型的计算，保留的是对缺失坐标积分后的数据似然；直接删除不完整行不是这项分解允许的操作。

对 $Y_i \stackrel{\text{iid}}{\sim} \mathcal{N}(\theta, \sigma^2)$ ，且 σ^2 已知，

$$-\log L(\theta; \mathbf{y}) = \frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \theta)^2 + C.$$

对 θ 求导并令其为零，得到 $\hat{\theta} = \bar{y}$ 。同一个样本平均也可由矩估计得到：总体矩 $\mathbb{E}_{\theta}[Y] = \theta$ ，于是令样本矩 $\bar{Y}$ 等于总体矩。似然法依赖完整分布形式，矩估计只使用选定矩条件。

“令导数为零”只寻找内点候选，不保证最大值存在或唯一。例如独立 Bernoulli 观测的似然为

$$L(p; \mathbf{y}) = p^{\sum_i y_i} (1-p)^{n-\sum_i y_i}, \quad p \in [0, 1].$$

当样本同时含有 0 和 1 时，唯一最大值是样本比例；全为 1 或全为 0 时，最大值分别落在边界 $p = 1$ 或 $p = 0$ 。若错误地把参数域写成开区间 $(0, 1)$ ，边界数据甚至只有上确界而没有最大似然估计。

压缩数据会丢掉细节，但有时这些细节与目标参数无关。例如 Bernoulli 样本的排列不同，只要成功次数相同，似然关于 p 的依赖就相同。充分性要求这种“保留全部参数信息”在整个指定模型中成立。

定义 10.97 充分统计量 设样本 $\mathbf{Y}$ 与统计量 $T(\mathbf{Y})$ 取值于标准 Borel 空间。若存在概率核 $K(t, \cdot)$ ，对每个 $\vartheta \in \Theta$ 都是 $\mathbf{Y}$ 给定 $T = t$ 的正则条件分布版本，而且 K 不依赖 ϑ ，则称 T 为该模型的充分统计量 (sufficient statistic)。各条件分布的等式按相应 P_ϑ^T -几乎处处意义理解。

它是在给定摘要后，样本其余部分不再携带关于参数的信息。在受同一个 σ 有限测度支配的模型中，若密度可分解为

$$p_\vartheta(\mathbf{y}) = g_\vartheta(T(\mathbf{y}))h(\mathbf{y}),$$

则因子分解定理说明 T 对 ϑ 充分。直观地说，给定 $T(\mathbf{Y}) = t$ 后，条件密度中的参数因子在归一化时抵消，剩余分布不含 ϑ 。在有限离散样本空间上，逆向关系也可直接算出。若 $\mathbf{Y} | T = t$ 的条件质量 $k(\mathbf{y} | t)$ 不依赖参数，则

$$p_\vartheta(\mathbf{y}) = p_\vartheta^T(T(\mathbf{y}))k(\mathbf{y} | T(\mathbf{y})),$$

也得到所需分解。一般连续情形的条件分布可能集中在低维纤维上，不能把这个离散乘法式未经参考测度核对就当成普通密度恒等式；因子分解定理负责一般受支配模型中的等价性。高斯位置模型中，已知方差时 $\sum_i Y_i$ 充分。充分性是相对于指定模型而言的；模型失配后，压缩掉的部分可能正好暴露失配。

M 估计、矩估计与仿真目标 似然以指定模型的对数密度作为拟合准则。若目标是中位数、希望减轻异常值影响，或不愿假定完整分布形状，就需要按目标另选样本准则。下面的表达把这些估计方法放在同一个框架中，但不同准则的总体最小点未必相同。

定义 10.98 M 估计 给定可测准则 $\rho(y, \vartheta)$, 当下面的最小点集合非空且存在可测选择时, M 估计 (M -estimation) 是从中选出的一个可测统计量:

$$\hat{\vartheta} \in \arg \min_{\vartheta \in \Theta} \frac{1}{n} \sum_{i=1}^n \rho(Y_i, \vartheta).$$

可微时, 一阶条件是估计方程

$$\frac{1}{n} \sum_{i=1}^n \psi(Y_i, \hat{\vartheta}) = 0, \quad \psi(y, \vartheta) = \nabla_{\vartheta} \rho(y, \vartheta).$$

取平方损失 $\rho(y, \theta) = (y - \theta)^2/2$ 时, $\psi(y, \theta) = \theta - y$, 每个残差在估计方程中的作用随其绝对值线性增长。若 $\mathbb{E}|Y| < \infty$, 绝对损失 $\rho(y, \theta) = |y - \theta|$ 的总体风险有限, 其最小点则是中位数: 目标函数的左右方向导数分别由 $\mathbb{P}(Y < \theta)$ 与 $\mathbb{P}(Y > \theta)$ 决定, 最优条件是 $\mathbb{P}(Y \leq \theta) \geq 1/2$ 且 $\mathbb{P}(Y \geq \theta) \geq 1/2$ 。因此平方与绝对准则即使使用同一批位置数据, 也在估计不同的总体泛函。

M 估计的一致性需要把经验准则与总体准则连接起来。记

$$Q_n(\vartheta) = \frac{1}{n} \sum_{i=1}^n \rho(Y_i, \vartheta), \quad Q(\vartheta) = \mathbb{E}[\rho(Y, \vartheta)].$$

假设 Θ 紧, Q 在唯一点 ϑ^* 取得最小值, 并且该最小值分离, 即对每个 $\epsilon > 0$,

$$\inf_{\|\vartheta - \vartheta^*\| \geq \epsilon} Q(\vartheta) > Q(\vartheta^*).$$

若 $\sup_{\vartheta \in \Theta} |Q_n(\vartheta) - Q(\vartheta)| \xrightarrow{\mathbb{P}} 0$, 且近似优化误差

$$Q_n(\hat{\vartheta}_n) - \inf_{\vartheta \in \Theta} Q_n(\vartheta) = o_{\mathbb{P}}(1),$$

其中 $o_{\mathbb{P}}(1)$ 表示该随机误差依概率趋于零, 则 $\hat{\vartheta}_n \xrightarrow{\mathbb{P}} \vartheta^*$ 。证明只需比较准则: 在任意固定的 ϵ 球外, 总体准则有正间隔; 当一致偏差和优化误差都小于该间隔的适当分数时, 经验近似最小点不可能位于球外。若参数空间不紧, 则必须另证估计点不会逃向无穷远; 若总体最小点不唯一, 结论只能指向最小点集合。

若真实分布 Q 不属于 $\mathcal{P}$, 就不能把拟合参数直接解释为真实机制的参数。其总体对数损失目标是:

定义 10.99 仿真参数 相对于共同参考测度的模型密度 p_{ϑ} , 假定所比较的 $\mathbb{E}_Q \log p_{\vartheta}(Y)$ 均有定义, 且下列最大点集合非空。集合中的任意一点

$$\vartheta^* \in \arg \max_{\vartheta} \mathbb{E}_Q [\log p_{\vartheta}(Y)]$$

称为该准则的仿真参数 (pseudo-true parameter)。

在经验准则一致逼近、总体极值唯一且分离等条件下, 最大似然估计才趋向该点; 多个最大点时须改为集合结论。它是模型族中按对数损失最接近真实分布的点, 不必等于科学问题中的真实量。估计量收敛并不自动证明模型正确。

稳健损失与影响函数 为了限制异常残差的作用, 可使用阈值 $c > 0$ 的 Huber 损失

$$\rho_c(r) = \begin{cases} r^2/2, & |r| \leq c, \\ c|r| - c^2/2, & |r| > c, \end{cases} \quad \psi_c(r) = \begin{cases} r, & |r| \leq c, \\ c \operatorname{sign}(r), & |r| > c. \end{cases}$$

这里 $\psi_c(r) = \rho'_c(r)$ 是损失对残差 r 的导数。由于 $\nabla_{\theta} \rho_c(y - \theta) = -\psi_c(y - \theta)$, 位置估计的参数梯度方程整体乘以 -1 后, 等价地写成 $\sum_i \psi_c(y_i - \hat{\theta}) = 0$ 。小残差仍按平方损失处理, 大残差的贡献被截在 $\pm c$ 。代价是: 即使高斯模型完全正确, 较小的 c 也会舍弃一部分有效幅度信息。

总体准则确定估计目标, 却没有说明少量异常观测会把它拉动多少。可以向分布 P 加入比例为 ϵ 的单点污染, 再考察目标的一阶变化。

定义 10.100 影响函数 设 T 为定义在概率分布上的实值或向量值统计泛函, Δ_z 为全部质量集中在 z 的概率测度。假定充分小的正 ϵ 所对应的污染分布仍在 T 的定义域内; 若右侧极限存在且有限, 定义影响函数 (influence function) 为

$$\operatorname{IF}(z; T, P) = \lim_{\epsilon \downarrow 0} \frac{T((1 - \epsilon)P + \epsilon \Delta_z) - T(P)}{\epsilon}.$$

例如对均值泛函, $\operatorname{IF}(z; T, P) = z - \mathbb{E}_P Y$: 同样少量的污染, 位置越远, 拉动越大。下面把这项敏感性接到估计方程。设统计泛函 $T(P)$ 由

$$\mathbb{E}_P[\psi(Y, T(P))] = 0$$

定义, 并令 $P_\epsilon = (1 - \epsilon)P + \epsilon\Delta_z$ 。记 $A = \mathbb{E}_P[\partial_\theta \psi(Y, T(P))] \neq 0$ 。假设估计方程在 $\epsilon = 0$ 附近可微, 微分可移入期望, 且所跟踪的根在局部唯一。对 $\mathbb{E}_{P_\epsilon}[\psi(Y, T(P_\epsilon))] = 0$ 在 $\epsilon = 0$ 处隐式求导, 得到

$$0 = -\mathbb{E}_P[\psi(Y, T(P))] + \psi(z, T(P)) + AT'(0),$$

第一项为零, 因此

$$\text{IF}(z; T, P) = T'(0) = -A^{-1}\psi(z, T(P)). \quad (10.53)$$

平方损失的位置影响随 z 无界, Huber 得分则有界。多维参数时, A 是估计方程对参数求导得到的 Jacobian 矩阵。若估计方程来自经验风险的梯度, 可以用相应 Hessian 近似它; 这还要求可微、局部可逆且所跟踪的估计根稳定。影响函数只描述污染比例在零附近的一阶敏感性, 不是任意污染比例下的误差上界; 在回归中, 截断残差也不会自动限制极端输入产生的高杠杆影响。

图 10.10 区分损失本身与它的导数。大残差的 Huber 损失仍持续增加, 并不是把异常观测删除; 被限制的是单个残差进入位置估计方程的得分。把“损失增长较慢”直接说成“整个估计量的影响有界”, 还需要式 (10.53) 中的局部曲率与输入条件。




图 10.10 平方损失与阈值 $c = 1$ 的 Huber 损失 (解析式教学图)。左图比较惩罚值, 右图比较对残差的导数; Huber 得分在 $[-1, 1]$ 内截断。横轴是构造残差, 不代表实测异常值分布。

频率学派把参数固定而把样本看作随机。Bayes 方法另给参数指定先验 $\pi(\theta)$, 观测后用

$$\pi(\theta | \mathbf{y}) = \frac{p(\mathbf{y} | \theta)\pi(\theta)}{\int p(\mathbf{y} | u)\pi(u) du}$$

得到后验分布 (posterior distribution)。它把似然提供的数据证据与先验假设合并。这个公式要求分母, 即模型证据, 严格为正且有限; 否则右侧不能定义概率分布。

对式 (10.52) 中的两组参数, 若先验还满足 $\pi(\theta, \psi) = \pi_\theta(\theta)\pi_\psi(\psi)$, 则联合后验的未归一化密度分成

$$\{L_{\text{data}}(\theta)\pi_\theta(\theta)\}\{g_\psi(\mathbf{r} | \mathbf{z}_{\text{obs}})\pi_\psi(\psi)\}.$$

在归一化常数严格为正且有限时, 对 ψ 积分只产生与 θ 无关的常数, 所以关于 θ 的后验也可省去机制因子。这就是 Bayes 分析还需要先验可分离的含义; 若先验把两组参数联系起来, 该因子一般会通过 ψ 影响 θ 的后验⁹。

得到后验分布以后, 若仍需报告一个参数值, 就要按报告错误的代价选择它。后验二阶矩有限时, 后验均值最小化后验平方损失。事实上, 对任意行动 a , 令 $m = \mathbb{E}[\theta | \mathbf{y}]$, 则

$$\mathbb{E}[(\theta - a)^2 | \mathbf{y}] = \text{Var}(\theta | \mathbf{y}) + (a - m)^2.$$

后验一阶绝对矩有限时, 后验中位数则最小化后验绝对损失, 其理由与前文总体中位数的左右方向导数相同。最大后验估计只选择相对于指定参考测度的密度峰值; 非线性重参数化会引入 Jacobian 因子, 因此峰值位置一般不保持不变。三种 Bayes 行动不必相同。

设

$$Y_i | \theta \stackrel{\text{iid}}{\sim} \mathcal{N}(\theta, \sigma^2), \quad \theta \sim \mathcal{N}(\mu_0, \tau_0^2).$$

配方后得到共轭更新

$$\theta | \mathbf{y} \sim \mathcal{N}(\mu_n, \tau_n^2), \quad \tau_n^{-2} = \tau_0^{-2} + n\sigma^{-2},$$

$$\mu_n = \tau_n^2 \left(\frac{\mu_0}{\tau_0^2} + \frac{n\bar{y}}{\sigma^2} \right).$$

后验均值是先验均值与样本均值的加权平均, 权重分别由先验方差 τ_0^2 和样本均值方差 σ^2/n 的倒数, 也就是精度决定。新读数的后验预测还须加上观测噪声, 见第 10.5.3.1 节。

离散比例也有同样的共轭结构。若 $Y_i | p \stackrel{\text{iid}}{\sim} \text{Bernoulli}(p)$ 且 $p \sim \text{Beta}(a, b)$, 观察到 $s = \sum_i Y_i$ 个成功后,

$$p | \mathbf{y} \sim \text{Beta}(a + s, b + n - s).$$

对 K 类计数 $(n_1, \dots, n_K)$, Dirichlet 先验 $\text{Dirichlet}(\alpha_1, \dots, \alpha_K)$ 相应更新为 $\text{Dirichlet}(\alpha_1 + n_1, \dots, \alpha_K + n_K)$ 。这些更新依赖给定比例后的条件独立抽样; 过度离散或来源相关时, 简单加计数会夸大信息量。

⁹ D. B. Rubin, *Inference and Missing Data* In *Biometrika*, 1976, vol. 63, no. 3, pp. 581–592

层次模型与部分汇聚 多个设备、标注者或任务的数据量很不均衡时，可令

$$\theta_g \mid \mu, \tau^2 \sim \mathcal{N}(\mu, \tau^2), \quad Y_{g,i} \mid \theta_g \sim \mathcal{N}(\theta_g, \sigma_g^2).$$

这里假设给定 (μ, τ^2) 后各组参数 θ_g 条件独立，并且给定全部组参数后，所有 $Y_{g,i}$ 也条件独立。若 μ, τ^2, σ_g^2 暂视为已知，且第 g 组有 n_g 个观测，则

$$\theta_g \mid \mathbf{y}_g, \mu, \tau^2 \sim \mathcal{N}(m_g, V_g), \quad V_g^{-1} = \tau^{-2} + n_g \sigma_g^{-2},$$

$$m_g = V_g \left(\frac{\mu}{\tau^2} + \frac{n_g \bar{y}_g}{\sigma_g^2} \right).$$

固定超参数时，第 g 组后验只依赖 $\mathbf{y}_g$ 以及外部给定的共同中心和尺度；小样本群组会更强地向共同中心 μ 收缩，其他组数据尚未进入该后验。当用全部群组数据估计共同超参数，或在完整 Bayes 模型中对其后验积分时，其他组数据才会通过共同超参数间接改变第 g 组的推断，从而形成组间信息共享。 $\tau^2 \rightarrow 0$ 接近完全汇聚， $\tau^2 \rightarrow \infty$ 接近各组独立估计，有限正尺度给出部分汇聚。若超参数由同一数据估计，这是经验 Bayes；若继续给它们指定先验，推断对象还包括超参数后验。组间共享信息依赖“群组参数来自共同总体”的结构假设。若群组机制不同或先验尺度过窄，收缩会掩盖真实差异。先验由研究者指定并不把固定物理参数变成随机生成的事实；Bayes 概率表达的是模型内部的不确定性。如果目标是某个预先给定的分位数，可以把样本从小到大排序。经验分布 $\hat{F}_n(y) = n^{-1} \sum_i \mathbb{I}_{\{Y_i \leq y\}}$ 的广义逆给出 $\hat{q} = Y_{([nq])}$ 。它估计的是总体分位数，不是未来读数的覆盖阈值；后者在共形预测中使用不同的秩修正。若总体在目标分位附近严格越过水平 q ，经验分布的统一收敛保证该估计一致；平坦区间、原子与不唯一目标则需按所选分位约定分析。

10.5.2.2 分布与条件函数的估计

经验分布把每个样本点赋质量 $1/n$ ，因而是完整的概率分布而不是密度曲线。独立同分布样本下，Glivenko–Cantelli 定理给出 $\sup_y |\hat{F}_n(y) - F(y)| \rightarrow 0$ 几乎必然；固定 y 的大数定律本身尚不等于这个统一结论。参数化方法则可报告 $P_{\hat{\theta}}$ ，例如 $\mathcal{N}(\bar{Y}, S^2)$ ，其有效性另外依赖模型限制。下面的平滑表示改变了分布或条件函数的形状，需要同时控制逼近误差与局部样本波动。有限维模型可能把真实分布限制得过强。非参数方法不预先固定有限个参数，但仍通过带宽、邻域或平滑度控制复杂度。以下令 $Y_1, \dots, Y_n$ 独立同分布，具有同一个一维密度 f ，并采用不依赖本批观测的带宽 $h = h_n > 0$ 。相关、选择或加权样本需要另行计算期望与协方差，不能直接使用下面的独立样本公式。给定宽度为 h 的分箱，直方图用“箱内样本数除以 nh ”作为箱内常数密度；移动箱边界可能改变估计。核密度估计则在每个样本点

附近放置一条由核决定的小曲线，再把这些曲线相加；核 K 决定形状，带宽 h 决定宽度：

$$\hat{f}_h(x) = \frac{1}{nh} \sum_{i=1}^n K\left(\frac{x - Y_i}{h}\right).$$

若 $K \geq 0$ 、积分为 1，则 $\hat{f}_h$ 本身是非负且积分为 1 的密度。为直接使用局部 Taylor 展开，以下采用一组充分条件： K 有界、紧支撑且对称，二阶矩记为 $\mu_2(K) = \int u^2 K(u) du$ ，并记 $R(K) = \int K(u)^2 du$ ；两者均有限。设 f 在内部点 x 的邻域二阶连续可微，则小带宽下核只涉及这个光滑邻域，由

$$\mathbb{E}[\hat{f}_h(x)] = \int K(u) f(x - hu) du$$

作 Taylor 展开，核的一阶矩因对称性消失，从而得到

$$\text{Bias}\{\hat{f}_h(x)\} = \frac{h^2 \mu_2(K)}{2} f''(x) + o(h^2),$$

$$\text{Var}\{\hat{f}_h(x)\} = \frac{f(x)R(K)}{nh} + o((nh)^{-1}),$$

其中渐近式取 $h \rightarrow 0$ 、 $nh \rightarrow \infty$ 。较大带宽降低方差却增加平滑偏差。边界附近因核质量落到支持集外，上述对称展开失效。在 d 维中，体积因子变为 h^d ，代表性点态方差阶数相应为 $1/(nh^d)$ 。因此维数增加时，同样窄的邻域内更难积累足够样本；一维的带宽结论不能直接照搬到高维。

局部预测与近邻 这里的观测改为 $(X_i, Y_i)_{i=1}^n$ ，假定它们来自同一联合分布且独立同分布， Y 可积。采用前面核密度估计中的非负、有界、紧支撑核 K 与确定带宽 $h > 0$ 。回归函数 $m(x) = \mathbb{E}[Y | X = x]$ 可由局部平均估计；以下比值只在权重和 $\sum_i K((X_i - x)/h) > 0$ 时定义：

$$\hat{m}_h(x) = \frac{\sum_i K((X_i - x)/h) Y_i}{\sum_i K((X_i - x)/h)}.$$

局部线性回归在 x 附近拟合 $a + b(X_i - x)$ ，在相应平滑条件下可减轻设计密度不均和边界偏差。下面的唯一拟合还要求局部加权设计满秩；在这个一维两参数问题中，即正权重的输入至少含两个不同取值。若权重和为零或设计退化，需扩大邻域或另给退化处理，不能照用比值或逆矩阵公式。

$$(\hat{a}, \hat{b}) \in \arg \min_{a, b} \sum_{i=1}^n K\left(\frac{X_i - x}{h}\right) \{Y_i - a - b(X_i - x)\}^2, \quad \hat{m}_{\text{local}}(x) = \hat{a}.$$

k 近邻取 $1 \leq k \leq n$ ，用离 x 最近的 k 个样本平均；距离并列时按预先指定的规则选择。维数增大时，为包含足够邻居必须扩大邻域。邻域越大，越难用局部 Taylor 展开准确描述其中的函数变化，这就是维数灾难的一种表现。

在例 10.96 的左边界 $x_0 = 0$ ，局部常数估计为

$$\hat{m}_h(0) = \frac{1 \times 9 + 0.75 \times 11 + 0.25 \times 13}{1 + 0.75 + 0.25} = 10.25.$$

局部线性拟合令 $u_i = x_i - x_0$ 。由这三个点可算得

$$S_0 = \sum_i w_i = 2, \quad S_1 = \sum_i w_i u_i = 1.5, \quad S_2 = \sum_i w_i u_i^2 = 3,$$

$$T_0 = \sum_i w_i y_i = 20.5, \quad T_1 = \sum_i w_i u_i y_i = 18.$$

加权正规方程给出

$$\hat{a} = \frac{S_2 T_0 - S_1 T_1}{S_0 S_2 - S_1^2} = 9.2, \quad \hat{b} = \frac{S_0 T_1 - S_1 T_0}{S_0 S_2 - S_1^2} = 1.4.$$

因此局部线性预测为 9.2，而局部常数预测为 10.25。在边界处，后者只能对单侧观测加权平均，前者还估计局部斜率并把直线截距放回 x_0 ；哪一个更接近真实条件均值仍取决于局部线性近似和带宽是否合适，不能由这一组数值单独决定。

图 10.11 显示这两个预测值的几何区别：水平线只改变高度，斜线同时解释输入位置与响应的局部变化，再把截距取回边界点。图中的观测和权重就是上面的三个教学数据；未画出未知的真实条件均值，因此不能从图上断言哪一种估计误差更小。




图 10.11 边界处的局部常数与局部线性拟合（教学数据图）。观测为 $(0, 9), (1, 11), (3, 13)$ ，权重为 1, 0.75, 0.25。蓝实线为加权常数 10.25，红虚线为 $9.2 + 1.4x$ ，边界 $x_0 = 0$ 处分别预测 10.25 和 9.2。

在上述独立同分布抽样下，这些方法的一致性需要邻域既缩小又包含越来越多样本。例如一维内部点处，若输入密度在 x 附近连续且为正，条

件均值足够光滑，条件方差局部有界，并取 $h \rightarrow 0$ 、 $nh \rightarrow \infty$ ，局部常数估计的平滑偏差消失，局部平均的方差也消失。输入密度与条件均值都二阶连续可微时，常用局部展开给出 $O(h^2)$ 的平滑偏差以及 $O((nh)^{-1})$ 的方差，因此平滑偏差的平方为 $O(h^4)$ ；精确常数还依赖核、输入密度与条件噪声。近邻版本相应要求 $k \rightarrow \infty$ 且 $k/n \rightarrow 0$ 。这些都是目标分布有局部覆盖时的内插结论；在训练输入密度为零的区域，缩小邻域无法产生新信息，外推保证必须来自额外结构假设。如果预测目标是条件分位数，可以按目标分位水平 q 设置高估与低估的权重。分位数回归采用下面的损失估计它；当 $q = 1/2$ 时，两种权重相同。假设 Y 可积，使下面损失的条件期望对几乎每个 x 有限。令

$$\rho_q(u) = u(q - \mathbb{I}_{\{u < 0\}}),$$

则条件 q 分位数最小化 $\mathbb{E}[\rho_q(Y - a) | X = x]$ 。固定 x 并记条件分布函数为 F ，目标对 a 的次梯度区间是

$$[F(a^-) - q, F(a) - q].$$

因此最优点恰好满足 $F(a^-) \leq q \leq F(a)$ ；连续严格递增时才简化为 $F(a) = q$ 。因此分位数损失的最小点集合正是 $\mathcal{Q}_q$ ，可能不唯一，而 $F^{-1}(q)$ 仍是其中按约定选出的单个代表。分位数回归直接估计条件分布的位置，不要求误差为高斯或方差恒定。实际分位数回归把条件分位函数写成 $a = f(x)$ ，最小化 $\sum_i \rho_q(Y_i - f(X_i))$ 及可能的正则项。线性、样条或其他函数类限制决定了可表示的条件分位形状；最小化同一损失不意味着所有表示有同样的偏差与覆盖保证。

10.5.3 未观测结果的预测

估计未知均值以后，新观测仍有自身噪声。平方损失下的点预测是预测分布的均值，绝对损失下是中位数；二元错判损失下选择概率较大的类别。先给出预测分布，再按损失选择一个点或一组允许值，才能避免把参数精度误当成结果精度。

10.5.3.1 预测分布与概率评价

若参数给定，条件预测使用概率核 $P_\theta(Y_{\text{new}} \in \cdot | X_{\text{new}} = x)$ ；把参数换成一个估计值，得到插件预测；Bayes 方法则按参数的后验概率对各个候选预测分布加权平均：

$$P(Y_{\text{new}} \in A | \mathbf{y}, x) = \int P_\theta(Y_{\text{new}} \in A | x) \pi(d\theta | \mathbf{y}),$$

这里假设给定参数后新观测与训练数据按模型条件独立。只代入一个参数值，通常不能反映其他候选参数仍可能成立的不确定性。在前述高斯共轭模型中，

$$Y_{n+1} | \mathbf{y} \sim \mathcal{N}(\mu_n, \sigma^2 + \tau_n^2).$$

其中 τ_n^2 是参数不确定性， σ^2 是新观测自身的噪声。点预测只给一个结果，概率预测则给出整个候选分布。若只奖励是否猜中最可能结果，报告完整概率并没有优势；评分必须鼓励把真实不确定性如实报告。

定义 10.101 适当评分规则 给定预测分布类 $\mathcal{P}$ ，评分规则 (scoring rule) $S(Q, y)$ ，即报告预测分布 Q 而结果为 y 时承担的损失。假定所比较的期望均有定义，且诚实报告的期望有限。若对每个 $P, Q \in \mathcal{P}$ 有 $\mathbb{E}_P S(P, Y) \leq \mathbb{E}_P S(Q, Y)$ ，就称评分规则 **适当** (proper)；若适用分布类中的最小点唯一，则称为严格适当。

它奖励诚实概率，而不是只检查最可能类别是否猜中。

先考虑有限结果集 $\mathcal{Y}$ ，并记 P, Q 的概率质量函数为 p, q 。本节只需有限离散情形的 **KL 散度** (Kullback-Leibler divergence)：

$$D_{\text{KL}}(P \| Q) = \sum_{y \in \mathcal{Y}} p(y) \log \frac{p(y)}{q(y)}.$$

其中约定 $0 \log(0/q) = 0$ ；只要存在 $p(y) > 0$ 而 $q(y) = 0$ ，就令散度为 $+\infty$ 。由 $-\log u \geq 1 - u$ 可得 $D_{\text{KL}}(P \| Q) \geq 0$ ，等号当且仅当 $P = Q$ 。这也可看成对凸函数 $-\log$ 应用 Jensen 不等式：在 P 的支持上平均 $q(y)/p(y)$ ，所得总和不超过 1。第 11 章将在一般测度空间上定义这一量，并系统讨论其性质。

离散结果的对数评分为 $S(Q, y) = -\log q(y)$ 。根据上述定义，其期望差满足

$$\mathbb{E}_P[S(Q, Y)] - \mathbb{E}_P[S(P, Y)] = \sum_{y \in \mathcal{Y}} p(y) \log \frac{p(y)}{q(y)} = D_{\text{KL}}(P \| Q) \geq 0.$$

因此对数评分是严格适当的；零预测概率遗漏真实分布的支持时，期望损失为无穷。连续密度版本还要求相对于共同参考测度定义密度，并保证相关对数期望有定义；改变参考坐标会改变单个对数密度值，但在合法换元下比较同一结果分布的期望差保持一致。

二元结果 $Y \in \{0, 1\}$ 的 Brier 评分为 $S(q, Y) = (q - Y)^2$ 。若真实事件概率为 p ，则

$$\mathbb{E}_p[(q - Y)^2] = p(q - 1)^2 + (1 - p)q^2 \quad (10.54)$$

$$= (q - p)^2 + p(1 - p). \quad (10.55)$$

第二项与报告 q 无关，所以唯一最优报告是 $q = p$ 。对数评分更强烈惩罚对已发生事件给极小概率，Brier 评分则有界；两者表达不同风险偏好。

对 K 个类别，令真实概率向量为 $\mathbf{p}$ ，报告为 $\mathbf{q}$ ，Brier 评分可写成 $S(\mathbf{q}, Y) = \sum_{k=1}^K (q_k - \mathbb{I}\{Y = k\})^2$ 。直接展开得到

$$\mathbb{E}_{\mathbf{p}}[S(\mathbf{q}, Y)] = \|\mathbf{q} - \mathbf{p}\|_2^2 + 1 - \|\mathbf{p}\|_2^2.$$

所以它在概率单纯形上同样严格适当，但控制的是概率向量的平方距离，不是对数密度比。

校准、区分能力与锐度 例如，把一批样本的事件概率都报为 0.2，就希望这类样本的长期发生率也为 0.2。校准检查概率值是否与相应样本的实际发生率一致；只检查类别猜得是否正确，回答不了这个问题。

定义 10.102 二元概率校准 设 $Y \in \{0, 1\}$ ，预测概率为随机变量 $Q \in [0, 1]$ 。若

$$\mathbb{E}[Y | Q] = Q \quad \text{几乎必然},$$

则称预测相对于当前联合总体分布是校准 (calibration) 的。等价地， $\mathbb{P}(Y = 1 | Q = q) = q$ 对 P_Q -几乎每个 q 成立。

它要求预测概率相同的一组样本具有相应的真实发生率，而不要求有限样本中每组频数恰好等于预测值。区分能力 (discrimination) 描述模型能否给更可能发生事件的样本更高分；锐度 (sharpness) 描述预测分布是否集中。对所有样本恒报基准发生率可以完美校准，却没有区分能力。锐度只有在校准前提下才值得追求。

令 $Q = \hat{p}(X)$ 、 $\eta(Q) = \mathbb{E}[Y | Q]$ ，再记总体发生率为 $\bar{p} = \mathbb{E}[Y]$ 。条件平方展开给出

$$\mathbb{E}[(Q - Y)^2] = \underbrace{\mathbb{E}[(Q - \eta(Q))^2]}_{\text{校准误差}} + \underbrace{\bar{p}(1 - \bar{p}) - \text{Var}(\eta(Q))}_{\text{剩余不可分辨误差}}.$$

第一项为零才表示相对于预测值本身校准；第二项随不同预测组的真实风险更可区分而减小。恒报 $\bar{p}$ 使第一项为零，却也使 $\text{Var}(\eta(Q)) = 0$ 。多类别校准相应要求 $\mathbb{P}(Y = k | \hat{\mathbf{p}}) = \hat{p}_k$ 对每个类别成立，逐类别边际校准通常弱于这个向量条件。

一个固定的两组例子可以把这几个性质分开。设两组各占总体一半，事件概率分别为 0.2, 0.8。如表 10.2，恒报 0.5 和按组报 0.2, 0.8 都校准；前者把两组混在一起，后者保留了风险差异。按组报 0, 1 保持相同排序，预测更集中，却把仍可能发生的意外结果说成不可能。

报告规则	两组概率	总体校准	期望 Brier 损失
恒报总体发生率	0.5, 0.5	是	0.25
如实报告组风险	0.2, 0.8	是	0.16
只保留确定类别	0, 1	否	0.20

表 10.2 同一个两组总体下的校准与区分能力。数值由 $\mathbb{E}[(q - Y)^2] = (q - p)^2 + p(1 - p)$ 逐组平均得到；后两行的类别排序相同，但概率准确性不同。

后处理校准与评价条件 温度缩放对分类 $\text{logit } \mathbf{z}$ 使用 $\text{softmax}(\mathbf{z}/T)$ ，在校准集上按对数损失估计 $T > 0$ 。它保持类别排序，只调整置信程度。保序回归则拟合单调的分数到概率映射，更灵活但更容易在小校准集上过拟合。给定排序分数 s_i ，其典型拟合问题是在 $q_1 \leq \dots \leq q_m$ 约束下最小化 $\sum_i (q_i - y_i)^2$ ；单调约束不等于总体校准保证。训练原预测器、拟合校准映射和评价最终效果，应分别使用独立的数据。若采用交叉拟合，每个样本的评价预测应由未使用该样本拟合的预测器和校准映射共同产生；部署总体若发生变化，旧映射也未必保持校准。分箱可靠性图只是把连续条件近似成有限组，箱内比例仍有抽样误差，且结果依赖分箱边界。适当评分、边际覆盖和校准分别评价分布损失、未来集合与条件发生率，不能互相替代。

10.5.3.2 预测集合与覆盖

预测集合 $C(\mathbf{Y})$ 在规定的训练数据与未来观测联合规律下要求 $\mathbb{P}\{Y_{n+1} \in C(\mathbf{Y})\} \geq 1 - \alpha$ ，其中 $0 < \alpha < 1$ 。在独立高斯位置模型 $Y_i \sim \mathcal{N}(\theta, \sigma^2)$ 且 σ 已知时，

$$Y_{n+1} - \bar{Y} \sim \mathcal{N}(0, \sigma^2(1 + 1/n)).$$

因为新噪声与训练均值独立，方差中除了估计均值的 σ^2/n ，还有新观测的 σ^2 。因此

$$C(\mathbf{Y}) = \left[\bar{Y} - z_{1-\alpha/2} \sigma \sqrt{1 + 1/n}, \bar{Y} + z_{1-\alpha/2} \sigma \sqrt{1 + 1/n} \right].$$

这里 z_p 是标准高斯分布的下 p 分位数。取 $1 - \alpha = 0.95$ ，例 10.96 的数值给出 $[6.40, 14.40]$ 。方差未知但仍为高斯独立样本时，可用 $\bar{Y} \pm t_{n-1, 1-\alpha/2} S \sqrt{1 + 1/n}$ 获得精确预测区间。其中 $n \geq 2$, $S^2 = (n-1)^{-1} \sum_i (Y_i - \bar{Y})^2$, $t_{\nu, p}$ 为自由度 ν 的 Student t 分布下 p 分位数。该分布是独立的 $Z \sim \mathcal{N}(0, 1)$ 与 $U \sim \chi^2_\nu$ 所成比值 $Z/\sqrt{U/\nu}$ 的规律。要在这里使用它，须把样本分成独立的均值方向和残差方向。

引理 10.103 高斯样本的均值与残差分解 设 $n \geq 2$ 、 $\sigma > 0$ ，且 $Y_1, \dots, Y_n$ 独立同分布于 $\mathcal{N}(\theta, \sigma^2)$ 。则

$$Z_0 = \frac{\sqrt{n}(\bar{Y} - \theta)}{\sigma} \sim \mathcal{N}(0, 1), \quad U = \frac{(n-1)S^2}{\sigma^2} \sim \chi_{n-1}^2,$$

且 Z_0 与 U 独立。

证明. 将标准化样本写成 $\boldsymbol{\varepsilon} = (\mathbf{Y} - \theta \mathbf{1})/\sigma \sim \mathcal{N}(\mathbf{0}, \mathbf{I}_n)$ 。选择首行为 $\mathbf{1}^\top/\sqrt{n}$ 的正交矩阵 $\mathbf{Q}$ ；其余行构成与 $\mathbf{1}$ 正交的残差方向。向量 $\mathbf{V} = \mathbf{Q}\boldsymbol{\varepsilon}$ 仍服从 $\mathcal{N}(\mathbf{0}, \mathbf{I}_n)$ ，所以各坐标是独立标准高斯。第一坐标 $V_1 = Z_0$ ；正交变换保持长度，并把常量方向与其正交补分开，故

$$\sum_{j=2}^n V_j^2 = \left\| \boldsymbol{\varepsilon} - \frac{\mathbf{1}\mathbf{1}^\top}{n} \boldsymbol{\varepsilon} \right\|_2^2 = \frac{1}{\sigma^2} \sum_{i=1}^n (Y_i - \bar{Y})^2 = U.$$

因此残差平方和具有 $n-1$ 个自由度，并与第一坐标独立。 ■

新观测 Y_{n+1} 独立于全部训练样本，所以 $(Y_{n+1}, \bar{Y})$ 与 S 独立，且 $(Y_{n+1} - \bar{Y})/(\sigma\sqrt{1+1/n})$ 是标准高斯。将它与上述 U 代入 t 分布定义，就得到所用的精确预测区间。这类保证依赖参数模型；只愿假设可交换性时，可改用下面的秩方法。设实值分数 $S_1, \dots, S_{m+1}$ 可交换，并暂假它们几乎必然没有并列值。令

$$R_{m+1} = 1 + \sum_{i=1}^m \mathbb{I}\{S_i < S_{m+1}\}$$

为最后一个分数从小到大的秩。由于交换任意两个坐标不改变联合分布，而无并列值时每个样本恰占一个秩，所以

$$\mathbb{P}(R_{m+1} = r) = \frac{1}{m+1}, \quad r = 1, \dots, m+1. \quad (10.56)$$

这是一项精确的有限样本结论，不依赖中心极限定理。

若存在并列值，使用“严格小于”的秩不再均匀。可以为每个分数附加独立连续随机数并按字典序打破并列，此时恢复精确均匀秩；也可以采用保守的不随机化分位数，得到覆盖率至少为目标值，但通常不再精确等于目标值。

拆分共形预测的有限样本覆盖 设训练数据用于拟合一个固定预测规则，随后有 m 个校准样本和一个未来样本。条件于训练数据，假设校准样本与未来样本可交换。用同一个不一致性函数计算

$$S_i = s(X_i, Y_i), \quad i = 1, \dots, m+1.$$

分数越大表示候选标签与预测规则越不相容。给定错误率 $\alpha \in (0, 1)$, 令

$$k = \lceil (m+1)(1-\alpha) \rceil.$$

若 $k \leq m$, 令 q 为前 m 个校准分数的第 k 小值; 若 $k = m+1$, 约定 $q = +\infty$ 。对新输入 X_{m+1} , 定义预测集合

$$C(X_{m+1}) = \{y : s(X_{m+1}, y) \leq q\}. \quad (10.57)$$

例如 $m = 9$ 、 $\alpha = 0.2$ 时, $k = \lceil 10 \times 0.8 \rceil = 8$ 。若排序后的校准分数为 $0.1, 0.2, \dots, 0.9$, 则 $q = 0.8$: 候选标签的分数为 0.75 时纳入集合, 为 0.85 时排除。若仍只有九个校准样本却要求 $\alpha = 0.05$, 则 $k = \lceil 9.5 \rceil = 10 = m+1$, 按约定得到 $q = +\infty$ 。这不是计算故障, 而是有限样本不足以用非随机秩给出如此高的非平凡覆盖水平。

定理 10.104 拆分共形的有限样本覆盖 在上述条件下,

$$\mathbb{P}(Y_{m+1} \in C(X_{m+1})) \geq 1 - \alpha.$$

证明. 先假设分数无并列值。若未来真实标签未被覆盖, 则 $S_{m+1} > q$, 所以未来分数在全部 $m+1$ 个分数中的秩严格大于 k 。由式 (10.56),

$$\mathbb{P}(S_{m+1} > q) = \mathbb{P}(R_{m+1} > k) = \frac{m+1-k}{m+1} \leq \alpha.$$

取补事件即得覆盖结论。

若有并列值, 采用集合定义中的 “ $\leq q$ ” 会把边界并列分数纳入预测集合。相较于随机打破并列后的精确秩, 这只会增加覆盖事件, 因此同一不等式仍成立。若希望得到更接近精确的覆盖率, 可显式随机化边界并列项, 但必须把该随机化纳入算法与概率空间。 ■

这里的概率保证是**边际覆盖**: 条件于训练数据后, 它仍对随机的校准样本和未来样本共同取平均; 若采用随机并列处理, 还包括该随机性。解除对训练数据的条件后, 总体覆盖率仍至少为 $1 - \alpha$ 。但这个结论一般不推出对每个固定输入 x 都有

$$\mathbb{P}(Y_{m+1} \in C(X_{m+1}) \mid X_{m+1} = x) \geq 1 - \alpha,$$

也不自动保证每个群组内都达到同一覆盖率。逐输入、逐群组或时间条件覆盖需要额外结构、假设或专门的校准方法, 不能仅由可交换秩推出。

证明依赖两处对称性。训练与校准拆分使评分规则在校准阶段保持固定; 校准样本与未来样本可交换, 使未来分数的秩没有特殊位置。若反复

查看校准误差后修改模型或分数函数，评分规则已依赖校准标签，条件可交换性可能被破坏。时间序列中的未来点通常也不能与过去点任意重排；自适应收集会让被选中的样本位置携带额外信息。此时失效的是均匀秩步骤，而不是把分位数索引稍作调整就能修复。第二卷“基础、理论和可信性”的“可靠性的保证”节建立具体预测范围后，将回用这一秩保证。分组校准需要在看见校准结果前规定群组，并有足够的组内可交换样本。边际覆盖平均了输入位置，不自动给出每个连续输入处的条件覆盖。

10.5.4 推断误差与假设检验

点估计可能偏离目标，区间可能漏掉目标，检验可能错误拒绝一个真命题，这些错误需要分别控制。本节先研究估计误差与区间覆盖，再研究假设检验。Bootstrap 用重抽样近似估计量的波动，置换检验则利用原假设下的重排对称性；选择数据或反复查看结果，都可能改变原有错误保证。

10.5.4.1 估计误差与效率

估计量的误差既来自系统偏移，也来自样本波动。对标量目标 θ ,

$$\begin{aligned}\mathbb{E}[(\hat{\theta} - \theta)^2] &= \mathbb{E}[(\hat{\theta} - \mathbb{E}\hat{\theta} + \mathbb{E}\hat{\theta} - \theta)^2] \\ &= \text{Var}(\hat{\theta}) + (\mathbb{E}[\hat{\theta}] - \theta)^2.\end{aligned}\quad (10.58)$$

交叉项期望为零，因而均方误差等于方差加偏差平方。无偏不等于误差最小；少量偏差可能换来更大的方差下降。

若 $\theta \in \mathbb{R}^d$ 并使用总平方误差，则

$$\mathbb{E}\|\hat{\theta} - \theta\|_2^2 = \text{tr}\{\text{Cov}(\hat{\theta})\} + \|\mathbb{E}\hat{\theta} - \theta\|_2^2.$$

这不是每个坐标风险的最大值，也不是任意方向风险。

在高斯位置例子中，取固定中心 μ_0 并令 $\tilde{\theta} = a\bar{Y} + (1-a)\mu_0$ ，则

$$\text{MSE}_{\theta}(\tilde{\theta}) = \frac{a^2\sigma^2}{n} + (1-a)^2(\mu_0 - \theta)^2.$$

当 θ 接近 μ_0 时，某些 $a < 1$ 可比无偏的样本均值具有更小有限样本均方误差；远离中心时，收缩偏差又可能占主导。比较结论必须固定目标、样本量和损失。

当任意 $\epsilon > 0$ 都满足 $\mathbb{P}_{\theta}(|\hat{\theta}_n - \theta| > \epsilon) \rightarrow 0$ 时，称估计量一致 (consistent)。一致性只描述样本量趋于无穷的极限，不给出当前样本的误差，也不排除有限样本偏差。若 $\mathbb{E}_{\theta}[(\hat{\theta}_n - \theta)^2] \rightarrow 0$ ，则称为均方一致；Markov 不等式说

明均方一致推出依概率一致，反向结论没有额外一致可积性时并不成立。对某些满足额外正则条件的估计量，还能进一步证明

$$\sqrt{n}(\hat{\theta}_n - \theta) \xrightarrow{d} \mathcal{N}(0, V).$$

这项性质称为渐近正态，它需要另行建立，并不由一致性自动推出。无偏性约束了平均位置，却尚未比较方差。把单一信号推广为一组带噪线性观测：给定设计矩阵 $\mathbf{X} \in \mathbb{R}^{n \times d}$ ，设

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\theta} + \boldsymbol{\varepsilon}, \quad \mathbb{E}[\boldsymbol{\varepsilon} | \mathbf{X}] = \mathbf{0}, \quad \text{Cov}(\boldsymbol{\varepsilon} | \mathbf{X}) = \sigma^2 \mathbf{I}_n, \quad \sigma^2 > 0. \quad (10.59)$$

不同观测的条件噪声方差相同且协方差为零；这里不要求独立或高斯噪声。列满秩使参数可识别，第6章的最小二乘解为 $\hat{\boldsymbol{\theta}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y}$ 。它是否在所有无偏估计中最佳，需要先限定比较类。

定理 10.105 Gauss–Markov 定理 在式 (10.59) 下，若 $\mathbf{X}$ 列满秩，则 $\hat{\boldsymbol{\theta}}$ 条件无偏，且 $\text{Cov}(\hat{\boldsymbol{\theta}} | \mathbf{X}) = \sigma^2 (\mathbf{X}^\top \mathbf{X})^{-1}$ 。对任何条件于 $\mathbf{X}$ 固定、对全部 $\boldsymbol{\theta}$ 均无偏的线性估计 $\tilde{\boldsymbol{\theta}} = \mathbf{C}\mathbf{Y}$ ，有

$$\text{Cov}(\tilde{\boldsymbol{\theta}} | \mathbf{X}) - \text{Cov}(\hat{\boldsymbol{\theta}} | \mathbf{X}) \geq \mathbf{0}.$$

证明. 记 $\mathbf{C}_0 = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top$ ，于是 $\mathbf{C}_0 \mathbf{X} = \mathbf{I}_d$ 。直接对 $\mathbf{C}_0 \mathbf{Y}$ 求条件均值和协方差，得到无偏性及所述协方差。任一线性估计对所有参数无偏，等价于 $\mathbf{C}\mathbf{X} = \mathbf{I}_d$ 。写 $\mathbf{C} = \mathbf{C}_0 + \mathbf{D}$ ，则 $\mathbf{D}\mathbf{X} = \mathbf{0}$ ，从而

$$\mathbf{C}_0 \mathbf{D}^\top = (\mathbf{X}^\top \mathbf{X})^{-1} (\mathbf{D}\mathbf{X})^\top = \mathbf{0}.$$

展开 $\sigma^2 \mathbf{C}\mathbf{C}^\top$ 时两个交叉项都为零，故协方差之差为 $\sigma^2 \mathbf{D}\mathbf{D}^\top$ 。对任意向量 $\mathbf{a}$ ，其二次型为 $\sigma^2 \|\mathbf{D}^\top \mathbf{a}\|_2^2 \geq 0$ ，即得半正定结论。 ■

半正定比较表示任意线性组合 $\mathbf{a}^\top \boldsymbol{\theta}$ 的方差都不更大，强于只比较各坐标方差。定理的比较类是线性无偏估计，不排除前面那类有偏收缩估计获得更小均方误差，也不把异方差或相关噪声包含进来。

若 $\mathbf{X} = \mathbf{1}_n$ ，参数就是共同均值，最小二乘退化为样本平均。任一无偏加权平均 $\sum_i a_i Y_i$ 满足 $\sum_i a_i = 1$ ；写 $a_i = 1/n + b_i$ ，则 $\sum_i b_i = 0$ ，其方差为 $\sigma^2 \sum_i a_i^2 = \sigma^2/n + \sigma^2 \sum_i b_i^2$ 。额外的不均衡权重只增加方差，给出矩阵证明的一个可逐项核对的特例。样本均值给出渐近正态的基本例子。若 $Y_1, \dots, Y_n$ 独立同分布，且 $\mathbb{E}[Y_i] = \theta$ 、 $0 < \text{Var}(Y_i) = \sigma^2 < \infty$ ，则中心极限定理给出

$$\sqrt{n}(\bar{Y} - \theta) \xrightarrow{d} \mathcal{N}(0, \sigma^2).$$

因此均值的渐近正态只需要有限方差，不要求观测本身服从高斯分布；在高斯位置模型中，这个正态分布关系对每个有限 n 已经精确成立。数值极限运算使用第 10.4.3.1 节的 Slutsky 和 Delta 方法。例如均值的标准误估计只要依概率趋向正确尺度，就可代入相应渐近统计量；这一条件不能由标准误的数值看起来合理来代替。一般估计方程的渐近式还要控制在随机估计点附近的斜率。设 Y_i 独立同分布，且 $\mathbb{E}[\psi(Y, \theta_0)] = 0$ ，记

$$A = \mathbb{E}[\partial_\theta \psi(Y, \theta_0)], \quad B = \text{Var}(\psi(Y, \theta_0)),$$

要求 $A \neq 0, B < \infty$ 。一组足够条件是： $\hat{\theta}$ 依概率趋于内点 θ_0 ； $\psi(y, \theta)$ 在其某个邻域内连续可微；经验导数 $n^{-1} \sum_i \partial_\theta \psi(Y_i, \theta)$ 在该邻域上一致依概率收敛到连续函数 $a(\theta) = \mathbb{E}[\partial_\theta \psi(Y, \theta)]$ ；估计方程残差 $r_n = n^{-1} \sum_i \psi(Y_i, \hat{\theta})$ 满足 $r_n = o_{\mathbb{P}}(n^{-1/2})$ 。一致性保证连接 θ_0 与 $\hat{\theta}$ 的线段以趋于一的概率留在该邻域内。沿线段积分导数，得到

$$A_n = \int_0^1 \frac{1}{n} \sum_{i=1}^n \partial_\theta \psi(Y_i, \theta_0 + t(\hat{\theta} - \theta_0)) dt \xrightarrow{\mathbb{P}} A,$$

$$r_n = \frac{1}{n} \sum_{i=1}^n \psi(Y_i, \theta_0) + A_n(\hat{\theta} - \theta_0).$$

随机斜率的收敛由一致导数控制与 a 的连续性共同给出，不能仅凭在固定点可微就断言。因 $A \neq 0$ ，以趋于一的概率可以除以 A_n ；再由中心极限定理与 Slutsky 得到

$$\sqrt{n}(\hat{\theta} - \theta_0) = -A^{-1} \frac{1}{\sqrt{n}} \sum_{i=1}^n \psi(Y_i, \theta_0) + o_{\mathbb{P}}(1),$$

故极限方差为 $A^{-2}B, B=0$ 时极限退化为零。多维情形将导数换为 Jacobian，要求其总体矩阵 A 非奇异，并对向量得分使用多元中心极限定理；极限协方差相应为 $A^{-1}B(A^{-1})^\top$ ，常称夹心协方差。模型正确的光滑似然在正则条件下可用信息恒等式化简它；模型失配时 A 与 B 通常不再是同一个信息量，夹心两侧不能省略。

得分、Fisher 信息与效率界 均方误差评价一个给定估计量，效率界进一步询问同一观测模型允许的估计精度。如果参数稍有改变，观测分布就明显变化，数据便更容易区分邻近参数。可以用对数似然的导数记录这种局部辨别能力。Fisher 信息 (Fisher information) 把这种局部差异写成可计算的量；本小节用它推导无偏估计的误差下界，统计几何章再解释它的几何意义。

定义 10.106 Fisher 信息矩阵 对开参数域上的受共同测度支配模型 p_θ , 固定参数内点 θ . 假设在 P_θ -几乎每个 x 处, $p_\theta(x) > 0$ 且 $\log p_\theta(x)$ 关于参数可微. 定义得分向量 $s_\theta(x) = \nabla_\theta \log p_\theta(x)$; 若 $\mathbb{E}_\theta \|s_\theta(X)\|_2^2 < \infty$, 该点的 Fisher 信息矩阵定义为

$$F(\theta) = \mathbb{E}_\theta [s_\theta(X)s_\theta(X)^\top]. \quad (10.60)$$

它是得分外积在模型分布下的平均, 必为半正定矩阵. 标量参数时退化为得分平方的期望; 这个定义本身不要求它等于负对数似然的期望 Hessian, 后一个恒等式还需正则条件.

下面固定一组足以支持常用恒等式的正则条件: 参数位于开区间, 所有密度相对于共同参考测度定义并具有共同正支持; 密度关于参数二次连续可微; 目标参数邻域内的一、二阶密度导数分别受可积函数控制; 得分二阶矩有限. 对得分 $s_\theta(Y) = \partial_\theta \log p_\theta(Y)$, 这些条件允许交换微分与积分, 于是

$$\mathbb{E}_\theta [s_\theta(Y)] = \int \partial_\theta p_\theta(y) dy = \partial_\theta 1 = 0.$$

再由 $\partial_\theta^2 \log p_\theta = (\partial_\theta^2 p_\theta)/p_\theta - s_\theta^2$ 积分, 得到

$$J(\theta) = \mathbb{E}_\theta [s_\theta(Y)^2] = -\mathbb{E}_\theta [\partial_\theta^2 \log p_\theta(Y)].$$

高斯位置观测的单样本信息为 $1/\sigma^2$, n 个独立观测的信息相加为 n/σ^2 . 下文记整批样本的得分为 $s_\theta(\mathbf{Y}) = \sum_{i=1}^n s_\theta(Y_i)$.

定理 10.107 Cramér-Rao 下界 设 $Y_1, \dots, Y_n$ 独立同分布于 p_θ , 并且上述正则条件成立且单样本 Fisher 信息满足 $0 < J(\theta) < \infty$. 若 $\hat{\tau}$ 对可微目标 $\tau(\theta)$ 无偏、二阶矩有限, 且其期望可对参数求导并移入积分, 则

$$\text{Var}_\theta(\hat{\tau}) \geq \frac{\tau'(\theta)^2}{nJ(\theta)}.$$

证明. 由无偏性 $\mathbb{E}_\theta[\hat{\tau}] = \tau(\theta)$ 对参数求导, 并把导数移入积分, 得到

$$\tau'(\theta) = \mathbb{E}_\theta[(\hat{\tau} - \tau(\theta))s_\theta(\mathbf{Y})].$$

Cauchy-Schwarz 不等式给出

$$\tau'(\theta)^2 \leq \text{Var}_\theta(\hat{\tau}) \text{Var}_\theta(s_\theta(\mathbf{Y})) = \text{Var}_\theta(\hat{\tau}) nJ(\theta),$$

整理即得结论. ■

这个界不是所有估计问题的普遍极限。参数位于边界、支持依赖参数、模型不可识别或 Fisher 信息奇异时，证明中的求导和除法可能失效；有偏估计量也要使用相应的偏差版本。对 $\theta \in \mathbb{R}^p$ 和可微目标 $\tau(\theta) \in \mathbb{R}^q$ ，向量参数的正则版本为

$$\text{Cov}_\theta(\hat{\tau}) \geq J_\tau(\theta) J_n(\theta)^{-1} J_\tau(\theta)^\top,$$

其中 $J_\tau \in \mathbb{R}^{q \times p}$ 是目标映射的 Jacobian， J_n 是整批样本的 Fisher 信息矩阵。这里要求信息矩阵可逆，但 Jacobian 可以是矩形或降秩矩阵；估计参数本身时 $\tau(\theta) = \theta$ ，故 $J_\tau = I_p$ 。矩阵结论也不能由逐坐标标量界直接拼接得到。上面的精度分析针对预先指定的估计程序。如果先用数据比较多个候选，再报告表现最好的一个，还会增加一项选择偏差：候选越多，误差被偶然低估的候选越容易胜出。解决办法是把选择和最终评价分开，或把“选择算法”整体作为待评价对象。为一个预先固定模型构造的区间，通常不能直接保证数据选中模型后的覆盖率。

例 10.96 还需要从两个预先给定的带宽中选择一个。用一个刻意简化、可精确计算的噪声模型说明选择偏差：假设两个带宽的真实预测均方误差都是 4，验证误差分别为

$$\hat{R}_j = 4 + \varepsilon_j, \quad \mathbb{P}(\varepsilon_j = 0.8) = \mathbb{P}(\varepsilon_j = -0.8) = \frac{1}{2}, \quad j = 1, 2,$$

并且两个误差独立。每个 $\hat{R}_j$ 单独都是无偏的，但两者最小值以概率 1/4 等于 4.8，以概率 3/4 等于 3.2，所以

$$\mathbb{E} \min(\hat{R}_1, \hat{R}_2) = \frac{1}{4} \times 4.8 + \frac{3}{4} \times 3.2 = 3.6.$$

把选中带宽的 3.6 当作未来风险，平均会低估 0.4。嵌套交叉验证或独立测试集的作用，是评价“比较两个带宽再选择”这一完整流程，而不是重新评价已知固定的单个带宽。

交叉验证与流程评价 交叉验证（cross-validation）把数据轮流分成训练部分和验证部分，估计“用同样训练流程在新数据上的预测误差”。它同时依赖训练规模、划分单位和调参流程。若用同一组折选择超参数又报告最优分数，结果仍含选择乐观偏差；需要嵌套交叉验证或独立测试集评估整个选择流程。

交叉验证各折的误差也不是彼此独立，因为训练集大量重叠。因此不能把 K 个折分数当成 K 个独立观测，再用普通样本方差构造过窄区间。若目标是比较两个算法，应在相同划分上计算配对差异，并把数据集抽样和训练随机性纳入评价设计；单次 K 折结果主要用于误差估计与模型选择，不自动提供精确的显著性检验。

10.5.4.2 区间估计与覆盖

点估计没有说明误差尺度。覆盖区间需要先说明概率来自哪一次随机化, 以及要覆盖的对象。

定义 10.108 置信、可信与预测覆盖 取 $0 < \alpha < 1$ 。置信区间 (confidence interval) 是一项重复抽样程序: 若每次按同一制度抽样并构造 $C(\mathbf{Y})$, 则对模型中的每个 θ 都有

$$\mathbb{P}_{\theta}\{\theta \in C(\mathbf{Y})\} \geq 1 - \alpha.$$

频率学派参数始终视作固定值; 数据固定后, 得到的区间也固定, 不能把它解释为“以 $1 - \alpha$ 概率包含参数”。Bayes可信区间 (credible interval) 则在给定数据和模型后满足 $\mathbb{P}(\theta \in C \mid \mathbf{y}) \geq 1 - \alpha$, 其数值依赖先验; 连续后验常可取到等号, 离散后验可能只能给出更大的覆盖概率。预测集合 (prediction set) 把覆盖对象改成未来结果, 在规定的训练样本与未来观测联合分布下要求 $\mathbb{P}\{Y_{n+1} \in C(\mathbf{Y})\} \geq 1 - \alpha$ 。三者的概率分别来自重复样本、参数后验和未来观测, 不能只按区间端点的外观解释。

在独立同分布的高斯位置模型中, 若方差已知, 则

$$\frac{\bar{Y} - \theta}{\sigma/\sqrt{n}} \sim \mathcal{N}(0, 1),$$

因而双侧置信区间为

$$\bar{Y} \pm z_{1-\alpha/2} \frac{\sigma}{\sqrt{n}}.$$

这一区间覆盖固定均值, 而第 10.5.3.2 节的区间覆盖新观测。取 $1 - \alpha = 0.95$, 对例 10.96, 均值置信区间为

$$10.4 \pm 1.96(2/5) = [9.62, 11.18].$$

它明显窄于下一次读数的预测区间 $[6.40, 14.40]$, 但不能替代后者。

图 10.12 显示这一区分在样本量增长时仍然存在: 均值标准误差按 $n^{-1/2}$ 减小, 而未来单次读数的噪声不会因历史样本增多而消失。因此收集更多校准数据会把位置参数确定得更精确, 却不能把一个有噪声的新读数限制到同样窄的范围。

方差未知时, 用

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (Y_i - \bar{Y})^2$$




图 10.12 已知 $\sigma = 2$ 的独立高斯位置模型中，两类区间半宽随样本量变化（解析式教学图）。使用四舍五入分位数 1.96，蓝实线为 $1.96\sigma/\sqrt{n}$ ，红虚线为 $1.96\sigma\sqrt{1 + 1/n}$ 。灰竖线标出例 10.96 的 $n = 25$ ，没有对任何实测数据重复抽样。

类型	覆盖对象	概率来源与必要条件
置信区间	固定总体参数	同一抽样制度下重复构造区间的覆盖率
可信区间	给定数据的参数后验	指定先验与似然形成的后验概率；不自动具有频率覆盖
预测区间	尚未观测的随机结果	训练样本与未来观测的联合分布；须包含新观测波动

表 10.3 三类区间的覆盖对象与概率来源。区间形式相似时，仍须从所覆盖的对象解释结论。

估计 σ^2 。在引理 10.103 的高斯独立样本条件下,

$$\frac{\bar{Y} - \theta}{S/\sqrt{n}} \sim t_{n-1},$$

所以把高斯分位数换成 t 分位数可得到精确置信区间。这里的精确性依赖高斯性;一般分布下它通常只是渐近近似。样本很小且分布偏斜、重尾时,机械使用该区间可能同时破坏中心和尾部覆盖。

双侧区间与双侧检验在相同模型、显著性水平和统计量下互为反演:若 θ_0 不在 $1 - \alpha$ 置信区间内,就拒绝 $H_0: \theta = \theta_0$ 。这种对应关系要求两者使用相同标准误与尾部规则。选择后区间、单侧检验或离散检验中,不能只凭表面上的阈值照搬这一关系。复杂估计量的抽样分布难以解析计算时,可以让经验数据模拟重复抽样。Bootstrap 从经验分布 $\hat{P}_n = n^{-1} \sum_i \Delta_{Y_i}$ 有放回抽取 n 个观测,并重新计算 $\hat{\tau}^*$ 。条件于原样本的 $\hat{\tau}^* - \hat{\tau}$ 近似 $\hat{\tau} - \tau(P)$ 的抽样波动。简单百分位区间取 Bootstrap 估计值的经验分位数,但对不光滑统计量、边界参数、极端尾部分位数或重尾小样本,近似可能很差。

对独立同分布、方差 $0 < \sigma^2 < \infty$ 的样本均值,可以把误差乘以 $\sqrt{n}$,明确比较原抽样与 Bootstrap 的极限分布。若 $\bar{Y}^*$ 由经验分布条件重抽样,则下述条件分布依概率弱收敛:

$$\mathcal{L}(\sqrt{n}(\bar{Y}^* - \bar{Y}) | Y) \Rightarrow \mathcal{N}(0, \sigma^2),$$

与 $\sqrt{n}(\bar{Y} - \mu)$ 的极限相同。这里条件分布随原样本而变,本身是随机对象。具体地,用 $\mathbb{E}_*$ 表示给定原数据后的重抽样期望,“依概率弱收敛”指对每个有界 Lipschitz 函数 f ,

$$\mathbb{E}_* f(\sqrt{n}(\bar{Y}^* - \bar{Y})) \xrightarrow{\mathbb{P}} \mathbb{E} f(Z), \quad Z \sim \mathcal{N}(0, \sigma^2).$$

外层的依概率收敛针对原数据的抽样随机性。

此处需要的中心极限定理允许抽样规律随 n 改变。把随机变量逐行排列,第 n 行有 n 项 $X_{n,1}, \dots, X_{n,n}$, 这样的排列称为三角阵列 (triangular array)。若每行内的变量独立、中心化,满足

$$\sum_{i=1}^n \mathbb{E} X_{n,i}^2 \longrightarrow \sigma^2 > 0, \quad \sum_{i=1}^n \mathbb{E} [X_{n,i}^2 \mathbb{I}\{|X_{n,i}| > \varepsilon\}] \longrightarrow 0$$

对每个 $\varepsilon > 0$ 成立,则行和趋于 $\mathcal{N}(0, \sigma^2)$ 。第二项称为 Lindeberg 条件,排除了由少数单项主导总波动的情况。这是所用的独立三角阵列中心极限定理;不要求不同行之间独立,完整证明见概率论教材¹⁰。

对给定原数据的重抽样取 $X_{n,i} = (Y_i^* - \bar{Y})/\sqrt{n}$ 。行和就是所研究的均值波动;条件均值为零,条件方差和是经验方差。经验均值等于 $\bar{Y}$, 经验方

¹⁰ O. Kallenberg, *Foundations of Modern Probability*, Springer, 2021, 3rd ed.

差依概率趋于 σ^2 ，但方差收敛本身还不足以保证条件中心极限定理。有限二阶矩还使每个 $\varepsilon > 0$ 对应的条件 Lindeberg 尾项满足

$$\frac{1}{n} \sum_{i=1}^n (Y_i - \bar{Y})^2 \mathbb{I}\{|Y_i - \bar{Y}| > \varepsilon \sqrt{n}\} \xrightarrow{\mathbb{P}} 0.$$

这个经验尾项恰好是上述阵列在条件分布下的 Lindeberg 和。其收敛可直接由有限二阶矩核对。以趋于一的概率 $|\bar{Y} - \mu| \leq \varepsilon \sqrt{n}/2$ ；在此事件上，若 $|Y_i - \bar{Y}| > \varepsilon \sqrt{n}$ ，则 $|Y_i - \mu| > \varepsilon \sqrt{n}/2$ 。又有

$$(Y_i - \bar{Y})^2 \leq 2(Y_i - \mu)^2 + 2(\bar{Y} - \mu)^2.$$

因此经验尾项被原中心平方尾的两倍经验平均加 $2(\bar{Y} - \mu)^2$ 控制。第一项的期望随截断阈值增大而趋零，由 Markov 不等式依概率趋零；第二项由大数定律趋零。

为把随机条件量接到确定阵列定理，可从任意原数据子列中再抽出一条子子列，使经验方差和所有正有理 ε 的尾项同时几乎必然收敛；这是引理 10.49 的可数对角应用。尾项关于阈值单调，故该共同满测集上所有正阈值的条件都成立。逐条固定这样的原数据实现，应用阵列定理便得到条件弱收敛；再用同一子列判据返回上述测试函数积分的依概率结论。该结论针对中心化、缩放后的条件分布；它本身不自动证明任意百分位区间具有高阶准确性。

例 10.96 中的经验分布均值为 10.4，经验方差按分母 n 计算恰为 4。因此单次 Bootstrap 抽样值满足

$$\mathbb{E}_*[Y^*] = 10.4, \quad \text{Var}_*(Y^*) = 4,$$

而二十五次有放回抽样的均值满足

$$\text{SE}_*(\bar{Y}^*) = \sqrt{\frac{4}{25}} = 0.4.$$

若中心化并按标准误标准化后的条件 Bootstrap 分布可由标准正态分布近似，则正态 Bootstrap 区间为 $10.4 \pm 1.96 \times 0.4 = [9.62, 11.18]$ ，与已知方差高斯区间在这个构造例中重合。重合来自经验方差刚好等于已知噪声方差以及均值的光滑性，不是 Bootstrap 总会复制参数区间的保证。

更一般的统计量可以用线性化研究，但须分别控制原抽样与重抽样的余项。即使已经证明

$$\hat{\tau} - \tau(P) = \frac{1}{n} \sum_{i=1}^n \text{IF}(Y_i; T, P) + o_{\mathbb{P}}(n^{-1/2}),$$

也还需证明条件重抽样展开, 例如对某个数据依赖的中心化函数 ϕ_n ,

$$\hat{\tau}^* - \hat{\tau} = \frac{1}{n} \sum_{i=1}^n \phi_n(Y_i^*) + r_n^*, \quad \mathbb{E}_* \phi_n(Y_i^*) = 0.$$

所需余项条件是: 对每个 $\varepsilon > 0$, $\mathbb{P}_*(\sqrt{n}|r_n^*| > \varepsilon) \xrightarrow{\mathbb{P}} 0$; 这就是这里的条件 $o_{\mathbb{P}_*}(n^{-1/2})$ 。若经验影响函数 ϕ_n 还满足条件中心极限定理, 且极限方差与原影响函数一致, 两边缩放后的分布才趋于同一极限。适当的统计泛函光滑性可以帮助建立这些条件, 不能只把原展开中的 P 换成 $\hat{P}_n$ 便认定已证明 Bootstrap 有效¹¹。

一个短反例说明为何必须单独检查重抽样。连续有限方差分布下, 取

$$\hat{\tau}_n = \bar{Y} + n^{-1/2} \{\text{样本中有重复值}\}.$$

原样本几乎必然没有重复值, 所以它具有与均值完全相同的原抽样展开。但从 n 个不同观测有放回抽 n 次, 全不重复的条件概率为 $n!/n^n \leq \exp(-(n-1)/2)$, 趋于零; 不等式来自 $\log(1-j/n) \leq -j/n$ 的逐项求和。于是 $\sqrt{n}(\hat{\tau}_n^* - \hat{\tau}_n)$ 额外平移约 1, 没有逼近原统计量的中心化极限。样本最大值之类统计量没有这种常规线性展开: 经验分布不会生成比当前最大值更大的观测, 简单 Bootstrap 便可能错误描述尾部。重采样单位必须跟独立单位一致。配对实验对整对数据重采样; 多个记录属于同一用户时对用户群组重采样; 时间相关数据使用保留局部依赖的块 Bootstrap。逐条重采样会把共享噪声误当作独立波动, 通常低估标准误。实验中可能每收集一批数据就查看一次区间, 并在精度足够时停止。若希望根据已有结果任意选择停止时刻, 仍保持规定的覆盖水平, 可以为所有查看时刻建立一项同时成立的高概率保证。

定义 10.109 置信序列 对参数为 θ 时的数据分布 $\mathbb{P}_\theta$, 数据依赖集合 $(C_t)_{t \geq 1}$ 若在时刻 t 由 $\mathcal{F}_t$ 确定, 且对每个允许的 θ 满足

$$\mathbb{P}_\theta(\theta \in C_t \text{ 对所有 } t \geq 1) \geq 1 - \delta,$$

则称为覆盖水平 $1 - \delta$ 的置信序列 (confidence sequence), 其中 $0 < \delta < 1$ 。

它在同一个高概率事件上覆盖所有时刻, 因而允许根据当前数据决定何时查看或停止。固定 n 的置信区间只承诺预先指定时刻的覆盖; 反复查看直到区间排除某个值, 会改变错误概率。一个可直接计算的标量构造来

¹¹ A. W. van der Vaart, *Asymptotic Statistics*, Cambridge University Press, 1998

自 Hoeffding 界。若 $X_i \in [0, 1]$ 独立同分布，均值为 μ ，给第 n 次查看分配错误预算 $\delta_n = \delta/[n(n+1)]$ ，则 $\sum_{n \geq 1} \delta_n = \delta$ 。定义

$$C_n = \left[\bar{X}_n - \sqrt{\frac{\log(2n(n+1)/\delta)}{2n}}, \bar{X}_n + \sqrt{\frac{\log(2n(n+1)/\delta)}{2n}} \right] \cap [0, 1].$$

对全部时刻的坏事件取并集，即得 $\mathbb{P}(\forall n, \mu \in C_n) \geq 1 - \delta$ 。取 $\delta = 0.05, n = 100$ ，半宽约为 0.254；固定时刻 Hoeffding 区间半宽约为 0.136。同时保证付出了更宽范围，这个简单预算构造也不是最紧的边界。条件均值恒为 μ 且条件范围仍为 $[0, 1]$ 时，条件 Hoeffding 论证给出同样控制；任意相关观测则不能直接使用。预先固定有限个候选时，可再将 δ 分给各候选以保证选择后的覆盖。无限搜索或用同一数据重新设计目标，需要额外统一控制或独立评价数据。

对于可预测的向量设计，下面回用第 10.4.5.3 节的自归一化界，把累计噪声转成参数置信椭球。取 $\mathbf{V}_0 = \lambda \mathbf{I}$ ， $\lambda > 0$ ，并定义岭回归估计

$$\hat{\theta}_t = \mathbf{V}_t^{-1} \sum_{s=1}^t \mathbf{x}_s y_s. \quad (10.61)$$

由式 (10.42)，

$$\mathbf{V}_t(\hat{\theta}_t - \theta^*) = \mathbf{S}_t - \lambda \theta^*.$$

若还知道 $\|\theta^*\|_2 \leq B$ ，三角不等式给出

$$\begin{aligned} \|\hat{\theta}_t - \theta^*\|_{\mathbf{V}_t} &\leq \|\mathbf{S}_t\|_{\mathbf{V}_t^{-1}} + \lambda \|\theta^*\|_{\mathbf{V}_t^{-1}} \\ &\leq R \sqrt{2 \log \left(\frac{\det(\mathbf{V}_t)^{1/2}}{\lambda^{d/2} \delta} \right)} + \sqrt{\lambda} B =: \beta_t(\delta). \end{aligned} \quad (10.62)$$

第二个不等式使用 $\mathbf{V}_t \geq \lambda \mathbf{I}$ 。因此

$$\mathcal{C}_t(\delta) = \{\theta : \|\theta - \hat{\theta}_t\|_{\mathbf{V}_t} \leq \beta_t(\delta)\}$$

在同一个概率至少为 $1 - \delta$ 的事件上，对所有 t 都包含真实参数。这是置信椭球而不是欧氏球：观测充分的方向较窄，信息不足的方向较宽。

示例 10.110 二维自适应查询 设 $d = 2, \lambda = 1$ ，每次只能在 $\mathbf{e}_1 = (1, 0)^\top$ 与 $\mathbf{e}_2 = (0, 1)^\top$ 中选择一个观测方向。算法可以在第 t 步比较当前椭球在两个方向上的宽度，据此安排下一次查询；这个选择只依赖过去，因而 $\mathbf{x}_t$ 可预测。

若前四次选择中 $\mathbf{e}_1$ 出现三次、 $\mathbf{e}_2$ 出现一次，则

$$\mathbf{V}_4 = \begin{pmatrix} 4 & 0 \\ 0 & 2 \end{pmatrix}, \quad \det(\mathbf{V}_4) = 8.$$

对任意方向 $\mathbf{x}$ ，椭球给出的预测误差满足

$$|\langle \mathbf{x}, \hat{\boldsymbol{\theta}}_4 - \boldsymbol{\theta}^* \rangle| \leq \beta_4(\delta) \|\mathbf{x}\|_{\mathbf{V}_4^{-1}}.$$

因而两个坐标方向的半宽分别与 $1/2$ 和 $1/\sqrt{2}$ 成比例。第一个方向访问更多，区间更窄；若据此把下一次查询安排到第二个方向，这就是由已有信息决定的自适应设计。定理仍然适用，因为它在每次新噪声产生之前固定当前方向，并在一个事件上同时控制全部时刻。

图 10.13 还比较了相同四次预算在两个方向各访问两次的情形：此时 $\mathbf{V}_4 = \text{diag}(3, 3)$ 。均衡访问扩大第一个方向的几何半宽，却缩小第二个方向的半宽；因此设计会改变误差的方向分配，不能只比较一个总访问数。图中把两条二次型的右侧统一设为 1，仅比较几何；真正的置信椭球还要分别乘上各自的 $\beta_4(\delta)$ ，其行列式项也会改变。




图 10.13 二维设计的归一化误差几何(解析式教学图)。蓝实线为 $\mathbf{e}^\top \text{diag}(4, 2)\mathbf{e} = 1$ ，红虚线为 $\mathbf{e}^\top \text{diag}(3, 3)\mathbf{e} = 1$ 。它们不是已经具有相同覆盖概率的数值置信区间；真实置信半径由式 (10.62) 另行确定。

这个例子也说明为什么不能把独立样本界中的 n 换成某个动作的访问次数。参数误差是向量，不同特征方向可能相关；置信宽度由 $\mathbf{x}^\top \mathbf{V}_t^{-1} \mathbf{x}$ 决定，而不是只由某个坐标被访问多少次决定。行列式项还反映了设计在全局方向上积累的信息，保证必须同时适用于算法可能选择的这些方向。

可预测设计与数据依赖的边界 自归一化界允许 $\mathbf{x}_t$ 依赖 $\mathcal{F}_{t-1}$ ，不允许它依赖当前 η_t 后再伪装成预先选择。若传感器先看到当前噪声再决定是否记录， $\mathbf{x}_t \eta_t$ 的条件平均可能不再为零，指数超鞅的第一步就会失败。类似地，模型失配使 $\mathbb{E}[y_t | \mathcal{F}_{t-1}, \mathbf{x}_t]$ 不等于 $\langle \mathbf{x}_t, \boldsymbol{\theta}^* \rangle$ 时，椭球会同时包含系统偏差与随机误差，不能继续解释为围绕同一个真实参数的置信集合。

条件次高斯性也不是有限方差的同义词。重尾噪声可能需要截断、稳健均值或只使用有限矩的其他序贯工具；直接套用式 (10.45) 会低估尾部。 λ 保证初期矩阵可逆并编码参数范数先验，但过大的 λ 会增加 $\sqrt{\lambda B}$ 偏差项。置信椭球控制统计误差，不保证选择策略会访问所有对任务重要的方向；探索是否充分仍要由设计规则与任务目标另行证明。

10.5.4.3 假设检验与错误控制

区间描述目标的可能范围，假设检验 (hypothesis testing) 则检查数据与一个命题是否相容。

定义 10.111 随机化检验函数 若单个观测的可测空间为 $\mathcal{Y}$ ，则随机化检验函数 (randomized test function) 是可测映射

$$\varphi : \mathcal{Y}^n \rightarrow [0, 1].$$

观察到 $\mathbf{Y} = \mathbf{y}$ 后，检验以概率 $\varphi(\mathbf{y})$ 拒绝原假设。等价地，可另取独立的 $U \sim \text{Unif}(0, 1)$ ，并在 $U \leq \varphi(\mathbf{y})$ 时拒绝。只取 0, 1 值的检验是非随机化特例，其拒绝域为 $R = \{\mathbf{y} : \varphi(\mathbf{y}) = 1\}$ 。

原假设 H_0 是一组待检验的参数或分布。检验首先限制它为真时被错误拒绝的概率，再考察其他参数下发现差异的能力。检验的大小与参数 θ 下的功效分别为

$$\sup_{\theta \in H_0} \mathbb{E}_\theta[\varphi(\mathbf{Y})], \quad \mathbb{E}_\theta[\varphi(\mathbf{Y})].$$

水平为 α 要求

$$\sup_{\theta \in H_0} \mathbb{E}_\theta[\varphi(\mathbf{Y})] \leq \alpha.$$

在 H_0 为真时拒绝是第一类错误；在备择 H_1 为真时不拒绝是第二类错误。对非随机化检验，这些期望分别退化为拒绝域概率。效应量描述差异有多大，样本量则影响能否把该差异从噪声中区分出来。

p 值 (p -value) 是在原假设下，得到至少与当前统计量同样极端结果的概率。

定义 10.112 有效 p 值 一个取值于 $[0, 1]$ 的可测统计量 $p(\mathbf{Y})$ 是复合原假设 H_0 下的有效 p 值, 若对每个 $u \in [0, 1]$ 都有

$$\sup_{\theta \in H_0} \mathbb{P}_\theta\{p(\mathbf{Y}) \leq u\} \leq u.$$

这个条件表示: 原假设成立时, p 值落到阈值 u 以下的概率不超过 u , 称为超均匀性。因此, 按阈值 α 拒绝可以控制第一类错误。观察到的 p 值不是原假设为真的概率, 也不是效应量。仍取已知 σ 的高斯位置模型, 检验 $H_0: \theta = 0$ 时

$$Z = \frac{\sqrt{n}\bar{Y}}{\sigma}, \quad p = 2\{1 - \Phi(|Z|)\}.$$

若 $\theta = \delta$, 双侧检验功效为

$$\mathbb{P}_\delta(|Z| > z_{1-\alpha/2}) = 1 - \Phi\left(z_{1-\alpha/2} - \frac{\sqrt{n}\delta}{\sigma}\right) + \Phi\left(-z_{1-\alpha/2} - \frac{\sqrt{n}\delta}{\sigma}\right).$$

小样本下“不显著”可能只表示功效不足。相同效应量在更大 n 下会得到更小的 p 值。

检验族还可反演为置信集合。对每个候选值 θ_0 , 设 $\varphi_{\theta_0}(\mathbf{Y}) \in \{0, 1\}$ 是水平不超过 α 的检验, 并定义

$$C(\mathbf{Y}) = \{\theta_0 : \varphi_{\theta_0}(\mathbf{Y}) = 0\}.$$

当真实值为 θ 时,

$$\mathbb{P}_\theta\{\theta \notin C(\mathbf{Y})\} = \mathbb{P}_\theta\{\varphi_\theta(\mathbf{Y}) = 1\} \leq \alpha,$$

所以 C 具有至少 $1 - \alpha$ 覆盖率。这里必须对同一模型、同一尾部规则和同一标准误反演; 选择后换检验或只挑有利方向会破坏证明。

示例 10.113 同一效应量下的证据与功效 设噪声标准差已知为 $\sigma = 2$, 观测均值为 $\bar{y} = 1$, 检验 $H_0: \theta = 0$ 。当 $n = 4$ 时, $Z = 1$, 双侧 p 值约为 0.317; 当 $n = 100$ 时, $Z = 5$, 双侧 p 值小于 10^{-6} 。两次实验报告的标准效应 $\bar{y}/\sigma = 0.5$ 相同, 证据强度却因标准误不同而变化。

若真实值确为 $\delta = 1$, 显著性水平为 0.05, 则 $n = 4$ 时双侧检验功效约为

$$1 - \Phi(1.96 - 1) + \Phi(-1.96 - 1) \approx 0.17.$$

此时未拒绝原假设并不支持“差异为零”。若实际问题把绝对差异不超过 0.2 视为等效，还需要针对 $\Delta = 0.2$ 设计等效检验；当前样本对这个更严格目标几乎没有辨识力。

似然比排序与 Neyman–Pearson 引理 若只比较两个完全指定的分布，希望在误报率有限的前提下尽量发现备择情形，就应该优先拒绝那些“在备择下更常见、在原假设下较少见”的观测。似然比对这些观测排序，下面的引理说明其最优性¹²。

定理 10.114 Neyman–Pearson 引理 对两个完全指定的简单假设 $H_0 : P = P_0$ 与 $H_1 : P = P_1$ ，设 $P_1 \ll P_0$ ，似然比为 $\Lambda = dP_1/dP_0$ 。在所有大小不超过 α 的检验中，拒绝大似然比并在边界适当随机化的检验具有最大功效。

证明. 取常数 c 与边界随机化概率，使检验 φ^* 满足 $\mathbb{E}_0[\varphi^*] = \alpha$ ，并在 $\Lambda > c$ 时拒绝、在 $\Lambda < c$ 时接受。对任意 $\mathbb{E}_0[\varphi] \leq \alpha$ 的检验，

$$(\varphi^* - \varphi)(\Lambda - c) \geq 0$$

逐点成立，因为 φ^* 在 $\Lambda > c$ 处取最大允许值，在 $\Lambda < c$ 处取最小允许值。对 P_0 积分得到

$$\mathbb{E}_1[\varphi^* - \varphi] \geq c \mathbb{E}_0[\varphi^* - \varphi] \geq 0.$$

所以 φ^* 的备择拒绝概率不小于任何同大小检验。 ■

这个结论只直接覆盖两个简单假设。复合假设需要处理未知参数，不一定存在一致最强检验。在隐私攻击审计中， P_0 与 P_1 可分别表示目标记录不在与在训练集时的输出分布；似然比给出理想攻击排序，但实际审计还要估计这两个分布并计入选择偏差。

列联表、渐近检验与不同命题 两个分类变量的列联表中，原假设为独立时，期望格数是

$$E_{r,c} = \frac{N_{r,\cdot} N_{\cdot,c}}{N}, \quad X^2 = \sum_{r,c} \frac{(N_{r,c} - E_{r,c})^2}{E_{r,c}}.$$

在独立抽样、固定维数且期望格数不过小时， X^2 近似服从自由度 $(R - 1)(C - 1)$ 的卡方分布。稀疏格数会破坏近似，可合并有科学意义的类别或使用精确、置换方法。条件独立检验还要控制第三个变量；把样本简单切成大量小层会带来新的稀疏性，不能由普通卡方检验自动解决。

差异检验把“无差异”放在原假设中。等效性检验先给出有实际含义的可接受差异界 $\Delta > 0$ 。记 $\delta = \theta_A - \theta_B$ ，两个单侧检验（two one-sided tests, TOST）把不等效原假设写成两个集合的并：

$$H_0 = H_{0,L} \cup H_{0,U}, \quad H_{0,L} : \delta \leq -\Delta, \quad H_{0,U} : \delta \geq \Delta.$$

对应备择为 $-\Delta < \delta < \Delta$ 。TOST 只有在水平 α 的下侧检验拒绝 $H_{0,L}$ ，并且水平 α 的上侧检验也拒绝 $H_{0,U}$ 时，才拒绝总体原假设。例如，若 $\hat{\delta}$ 的标准误为 s ，且标准化统计量服从相应正态近似，拒绝条件为

$$\frac{\hat{\delta} + \Delta}{s} > z_{1-\alpha} \quad \text{且} \quad \frac{\hat{\delta} - \Delta}{s} < z_{\alpha}. \quad (10.63)$$

这等价于把双侧 $1 - 2\alpha$ 置信区间完整放入 $(-\Delta, \Delta)$ 。总体第一类错误并非 2α ：只要 $\delta \in H_0$ ，至少有一个单侧原假设为真，而总体拒绝事件包含在拒绝这个真原假设的事件中，所以其概率至多为 α 。非劣效检验只排除一个方向，例如 $H_0 : \delta \leq -\Delta$ 。未拒绝差异检验的零假设不等于证明等效。置换检验（permutation test）近似的不是估计量抽样分布，而是零假设下标签可交换时的随机化分布。两组观测在“处理标签不影响联合分布”的原假设下，可反复打乱标签并重算组间差异。若分配机制只允许在区组内交换，就必须在区组内置换；任意全局打乱会制造实验中不可能出现的分配。

若允许的置换集合有 M 个元素，并把观测统计量与全部置换统计量一起排序，则交换对称性使真实排列的秩在这些位置上均匀；存在并列时使用

$$p_{\text{perm}} = \frac{\#\{\text{置换统计量不小于观测值}\}}{M}$$

得到超均匀而可能保守的 p 值。若只随机抽取 B 个置换，常用 $(1 + \#\{\text{抽样置换不小于观测值}\})/(B + 1)$ 保留有限模拟下的保守性。仅有两组均值相等并不保证整批标签可交换；交换性必须来自更强的零假设或随机分配设计。单个检验的第一类错误为 α ，不代表同时尝试许多候选后仍只有 α 的误报概率。若 m 个原假设都为真，联合界给出

$$\mathbb{P}(\text{至少一次误拒绝}) \leq \sum_{j=1}^m \mathbb{P}(\text{拒绝 } H_j) \leq m\alpha.$$

Bonferroni 方法把每项阈值设为 α/m ，从而控制族错误率（family-wise error rate, FWER）。它不要求检验独立，但候选很多时可能保守。

Holm 方法把 p 值从小到大排序，并依次将 $p_{(j)}$ 与 $\alpha/(m - j + 1)$ 比较，遇到第一个未拒绝项即停止。若第一个被错误拒绝的真原假设位于位置 j ，设真原假设总数为 m_0 ，则前 $j - 1$ 项均为假原假设，所以 $m - j + 1 \geq m_0$ 。该真原假设的 p 值因而不超过 $\alpha/(m - j + 1) \leq \alpha/m_0$ 。对全部 m_0 个真

原假设应用联合界，便把发生任一错误拒绝的概率控制在 α 以内。它与 Bonferroni 一样不要求独立，但利用了逐步比较。

当目标是控制所有拒绝中错误发现的期望比例时，可使用 **错误发现率** (false discovery rate, FDR)。设 R 为拒绝的总数、 V 为其中被错误拒绝的真原假设数，则

$$\text{FDR} = \mathbb{E} \left[\frac{V}{\max(R, 1)} \right].$$

当 $R = 0$ 时，错误发现比例约定为零；这是随机比例的期望，不是 $\mathbb{E}V/\mathbb{E}R$ 。Benjamini-Hochberg 过程将 p 值排序为 $p_{(1)} \leq \dots \leq p_{(m)}$ ，找最大

$$k = \max \left\{ j : p_{(j)} \leq \frac{j}{m} q \right\},$$

并拒绝前 k 项；若集合为空，则取 $k = 0$ ，不拒绝任何假设。若全部 p 值相互独立，且每个真原假设下的 p 值满足 $\mathbb{P}(p_j \leq u) \leq u$ ($0 \leq u \leq 1$)，该过程控制 FDR 不超过目标 $q \in (0, 1)$ ¹³。扩展到依赖检验需要更精确的联合分布条件，不能仅凭两两正相关或任意依赖就沿用这项保证。

持续查看同一数据也构成选择。固定时刻满足 $\mathbb{P}(p_t \leq \alpha) \leq \alpha$ 并不推出 $\mathbb{P}(\exists t : p_t \leq \alpha) \leq \alpha$ 。预先规定查看次数可分配 α 预算；更灵活的停止规则需要序贯检验、置信序列或对整个证据过程的控制。停止规则属于推断程序的一部分，不能在看到结果后删去。

一种单次证据是 e 值 (e-value)：非负统计量 E 若在每个零假设分布 P 下满足 $\mathbb{E}_P E \leq 1$ ，就称为有效 e 值。由 Markov 不等式， $P(E \geq 1/\alpha) \leq \alpha$ ，所以大值可以用来拒绝零假设。但逐个固定时刻的 E_t 都是有效 e 值，仍不足以保证可以任意停止；下文用非负超鞅给出一种能同时控制所有时刻的证据过程。

定义 10.109 的**置信序列** (confidence sequence) 把所有时刻的覆盖放在同一个高概率事件中。这比每个固定时刻各自覆盖更强，因为允许依据当前数据决定何时停止查看。若 (E_t) 在原假设下是从 $E_0 = 1$ 开始的非负超鞅，则 Ville 不等式给出

$$\mathbb{P}_0 \left\{ \sup_{t \geq 0} E_t \geq \frac{1}{\alpha} \right\} \leq \alpha.$$

因此可以在任意由过去信息决定的停止时刻按阈值查看 E_t ，而不增加这项越界概率。这不表示停止后的点估计无偏，也不表示同时尝试多个证据过程无需额外控制；覆盖、估计偏差和模型选择证据仍是不同问题。

10.5.5 模型比较与观测设计

分析已有数据时，要决定哪个候选模型更合适；还有采样预算时，要决定下一次测什么。前者需要说明比较训练拟合、未来误差还是模型证据，后

¹³ Y. Benjamini, Y. Hochberg, *Controlling the False Discovery Rate: A Practical and Powerful Approach to Multiple Testing* In Journal of the Royal Statistical Society: Series B (Methodological), 1995, vol. 57, no. 1, pp. 289–300

者需要说明希望降低哪一项任务误差。使用的准则不同，得到的选择也可能不同。

10.5.5.1 给定观测下的模型比较

前面已说明怎样评价估计和预测的误差。现在要据此选择模型：不同准则可能偏好不同模型，所以先说明各自比较什么，再讨论难算的模型证据怎样近似，以及近似需要哪些条件。

预测、似然与边缘似然 模型选择准则并非都在回答同一问题。独立测试误差比较未来预测；训练似然衡量已观测数据在拟合参数下的密度；边缘似然

$$p(\mathbf{y} | M) = \int p(\mathbf{y} | \boldsymbol{\vartheta}, M) \pi(\boldsymbol{\vartheta} | M) d\boldsymbol{\vartheta}$$

对参数不确定性积分；编码长度则把模型和数据的描述代价相加。一个模型可能训练似然高，却因复杂度、先验体积或泛化误差而不被其他准则选择。

给两个候选模型都指定参数先验后，可以比较它们生成当前数据的边缘似然。这项比较先按参数先验对各候选参数下的数据密度加权平均，再用比值更新模型之间的相对支持程度。

定义 10.115 Bayes 因子 两个模型 M_1, M_0 的 Bayes 因子 (Bayes factor) 是

$$\text{BF}_{1,0} = \frac{p(\mathbf{y} | M_1)}{p(\mathbf{y} | M_0)}.$$

这里两个边缘似然都由概率先验得到；所比较的数据处，分母严格为正且有限，分子有限且可为零。

Bayes 因子更新的是模型间先验赔率，不是与先验无关的“模型为真概率”。在高斯位置模型中，若 $\theta \sim \mathcal{N}(0, A^2)$ ，则 $\bar{Y} \sim \mathcal{N}(0, A^2 + \sigma^2/n)$ 。保持似然峰值不变而增大 A 会把先验质量摊到更宽区域；对固定 $\bar{y}$ ，当 $A \rightarrow \infty$ 时该边缘密度趋于零。这正是模型证据依赖参数先验尺度的一个可复核例子。

Laplace 近似与 BIC 边缘似然通常需要一个难算的高维积分。若被积函数主要集中在一个光滑峰值附近，可以在峰值处作二次展开，把附近形状近似为高斯，再证明远处的积分足够小。下面的条件分别保证峰值近似有效和尾部不会主导结果。

定理 10.116 固定维 Laplace 局部积分近似 设 $\Theta \subseteq \mathbb{R}^d$ 为可测集, $\hat{\boldsymbol{\vartheta}} \in \text{int}(\Theta)$ 。函数 $h : \Theta \rightarrow \mathbb{R}$ 可测, 并在 $\hat{\boldsymbol{\vartheta}}$ 的某个邻域内二阶连续可微; 该点是 h 在 Θ 上的唯一全局最大点, 且 $\mathbf{H} = -\nabla^2 h(\hat{\boldsymbol{\vartheta}})$ 正定。函数 $g : \Theta \rightarrow [0, \infty)$ 局部可积, 在该点的某个邻域内连续, 并满足 $g(\hat{\boldsymbol{\vartheta}}) > 0$ 。

进一步假设存在 $\delta, \eta > 0$ 和 $n_0 \geq 1$, 使 $\overline{B_\delta(\hat{\boldsymbol{\vartheta}})} \subseteq \Theta$, h, g 在该闭球所在的邻域内分别满足上述光滑性与连续性, 并且

$$\sup_{\boldsymbol{\vartheta} \in \Theta \setminus B_\delta(\hat{\boldsymbol{\vartheta}})} h(\boldsymbol{\vartheta}) \leq h(\hat{\boldsymbol{\vartheta}}) - \eta, \quad \int_{\Theta} \exp\{n_0[h(\boldsymbol{\vartheta}) - h(\hat{\boldsymbol{\vartheta}})]\} g(\boldsymbol{\vartheta}) d\boldsymbol{\vartheta} < \infty.$$

则当 $n \rightarrow \infty$ 时,

$$\int_{\Theta} \exp\{nh(\boldsymbol{\vartheta})\} g(\boldsymbol{\vartheta}) d\boldsymbol{\vartheta} = \exp\{nh(\hat{\boldsymbol{\vartheta}})\} g(\hat{\boldsymbol{\vartheta}}) \left(\frac{2\pi}{n}\right)^{d/2} |\mathbf{H}|^{-1/2} \{1 + o(1)\}.$$

证明. 正定性与二阶连续性保证: 必要时缩小 δ , 存在 $c > 0$, 使闭球内有

$$h(\boldsymbol{\vartheta}) - h(\hat{\boldsymbol{\vartheta}}) \leq -c\|\boldsymbol{\vartheta} - \hat{\boldsymbol{\vartheta}}\|_2^2.$$

缩小闭球后, 原闭球中剩余的紧致环带由唯一最大性给出严格间隔; 把它与原来的尾部间隔合并, 仍可取某个 $\eta > 0$ 满足定理中的一致上界。另一方面, 在最大点附近作多元 Taylor 展开:

$$h(\boldsymbol{\vartheta}) = h(\hat{\boldsymbol{\vartheta}}) - \frac{1}{2}(\boldsymbol{\vartheta} - \hat{\boldsymbol{\vartheta}})^\top \mathbf{H}(\boldsymbol{\vartheta} - \hat{\boldsymbol{\vartheta}}) + o(\|\boldsymbol{\vartheta} - \hat{\boldsymbol{\vartheta}}\|_2^2).$$

令 $\mathbf{u} = \sqrt{n} \mathbf{H}^{1/2}(\boldsymbol{\vartheta} - \hat{\boldsymbol{\vartheta}})$, 则逆变换的 Jacobian 行列式绝对值为 $n^{-d/2} |\mathbf{H}|^{-1/2}$, 即 $d\boldsymbol{\vartheta} = n^{-d/2} |\mathbf{H}|^{-1/2} d\mathbf{u}$ 。对每个固定的 $\mathbf{u}$, Taylor 展开与 g 的连续性使变换后的被积函数收敛到 $g(\hat{\boldsymbol{\vartheta}}) \exp(-\|\mathbf{u}\|_2^2/2)$ 。局部二次上界和 g 在闭球上的有界性给出可积的高斯控制函数, 因此支配收敛定理给出

$$\int_{B_\delta(\hat{\boldsymbol{\vartheta}})} \exp\{n[h(\boldsymbol{\vartheta}) - h(\hat{\boldsymbol{\vartheta}})]\} g(\boldsymbol{\vartheta}) d\boldsymbol{\vartheta} = n^{-d/2} |\mathbf{H}|^{-1/2} g(\hat{\boldsymbol{\vartheta}}) (2\pi)^{d/2} \{1 + o(1)\}.$$

闭球外的尾项满足

$$\int_{\Theta \setminus B_\delta(\hat{\boldsymbol{\vartheta}})} e^{n[h(\boldsymbol{\vartheta}) - h(\hat{\boldsymbol{\vartheta}})]} g(\boldsymbol{\vartheta}) d\boldsymbol{\vartheta} \leq e^{-(n-n_0)\eta} \int_{\Theta} e^{n_0[h(\boldsymbol{\vartheta}) - h(\hat{\boldsymbol{\vartheta}})]} g(\boldsymbol{\vartheta}) d\boldsymbol{\vartheta} = o(n^{-d/2}).$$

局部主项与该尾项相加即得结论。 ■

上一定理描述固定函数 h 的基本形式。在正则独立样本模型中, 实际处理的是随机函数序列

$$nh_n(\boldsymbol{\vartheta}) = \ell_n(\boldsymbol{\vartheta}) = \sum_{i=1}^n \log p_{\boldsymbol{\vartheta}}(y_i), \quad g(\boldsymbol{\vartheta}) = \pi(\boldsymbol{\vartheta}).$$

若极大似然估计以内点唯一最大点的形式收敛, 归一化观测信息矩阵收敛到正定极限, 先验在极限点附近连续且为正, 并且局部二次展开与尾部控制对该序列一致成立, 则相同论证给出

$$\log p(\mathbf{y} | M) = \ell_n(\hat{\boldsymbol{\vartheta}}) - \frac{d}{2} \log n + O_{\mathbb{P}}(1).$$

对固定的有限候选模型集合, 乘以 -2 并只保留随 n 发散的项, 得到常用形式

$$\text{BIC} = -2\ell_n(\hat{\boldsymbol{\vartheta}}) + d \log n.$$

这里的 $d \log n$ 项来自积分: 后验的高密度区域体积按 $n^{-d/2}$ 缩小, 取对数再乘以 -2 , 便出现了这一项。

AIC、描述长度与比较口径 在独立、固定维且正则的最大似然设定中, 常用

$$\text{AIC} = -2\ell_n(\hat{\boldsymbol{\vartheta}}) + 2d.$$

其中 $2d$ 用于一阶校正: 模型在训练数据上的对数损失通常比新样本上的损失更小, 因为参数也用这批数据拟合。AIC 试图修正这种乐观偏差, 评价未来预测的对数损失; 模型失配时还要核对适用的协方差校正, 不能只数参数。BIC 近似特定先验下的边缘似然, 常以候选中存在真模型的正则渐近为背景。最小描述长度 (minimum description length, MDL) 则先规定可解码的模型代码与给定模型后的数据代码, 再最小化二者总长度; 更换编码对象或精度约定会改变有限样本准则。三者惩罚形式相似时也不能互换解释, 更不能共享未经证明的选择一致性。

混合模型的标签交换、参数位于边界、额外成分权重为零或 Fisher 信息奇异时, 最大点可能不唯一, 局部曲率可能退化, 常规 Laplace 展开和 $d \log n$ 惩罚随之失效。此时应使用适合奇异模型的方法、数值积分或明确的近似; 近似边缘似然不能写成精确证据。

10.5.5.2 给定预算下的观测设计

推断质量不仅由分析方法决定, 也由数据如何取得决定。每个对象在各处理下本会产生的结果称为潜在结果, 正式的因果目标将在第 12 章定义。随机分配使处理指派在设计上独立于这些预先固定的结果, 从而把系统差异转成可量化的随机误差。配对对照先按对象或关键协变量配对, 再在对内

比较, 可消除共享噪声。若配对质量差或分析时忽略配对, 预期的方差收益不会自动出现。

先看最简单的两组位置模型。若随机分配后两组分别有 n_A, n_B 个独立观测, 均值为 μ_A, μ_B , 方差为 σ_A^2, σ_B^2 , 则

$$\hat{\Delta} = \bar{Y}_A - \bar{Y}_B, \quad \mathbb{E}[\hat{\Delta}] = \mu_A - \mu_B,$$

$$\text{Var}(\hat{\Delta}) = \frac{\sigma_A^2}{n_A} + \frac{\sigma_B^2}{n_B}.$$

随机化建立的是处理指派与处理前对象特征之间的概率关系, 并不要求两种处理下的结果服从同一分布。上式还假设组间独立且组内方差有限; 配对随机化应改为分析对内差值。它提供的是设计下的可复核比较, 潜在结果目标及从试验人群向目标总体的推广条件由第 12 章继续建立。

消融实验删除一个组件并保持其他条件不变, 用来判断该组件对整体结果的增量贡献。它不能在组件强交互时给出唯一的“独立贡献”, 也不能用不同训练预算的两个系统冒充单因素比较。基线、随机种子、停止规则和评价集都应在比较前固定。

学习曲线记录: 随着训练样本量或计算量增加, 模型在未参与训练的验证数据上的表现怎样变化。只报告最终点无法区分方法是数据效率更高, 还是只是使用了更多数据和算力。实验至少要区分数据预算、计算预算与评价时间预算: 收集更多标签、搜索更多配置和反复占用测试集是三种不同资源。

预算下的精度与信息价值 预算分配应对应希望降低的误差。若两组单位观测成本相同且 $n_A + n_B = N$, 最小化上面的均值差方差可得

$$\frac{n_A}{n_B} = \frac{\sigma_A}{\sigma_B}.$$

这是对 n_A 求导或用 Cauchy-Schwarz 得到的 Neyman 分配: 波动较大的组需要更多观测。方差未知时要用先验信息或先导样本估计, 估计误差也应计入设计; 整数、最低组规模 and 不同成本会改变解。

线性观测模型 $\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$ 可以说明怎样为多个参数方向安排观测, 其中 $\mathbf{X} \in \mathbb{R}^{n \times d}$ 、 $\boldsymbol{\beta}, \mathbf{a} \in \mathbb{R}^d$ 。给定满列秩设计矩阵 $\mathbf{X}$, 假设 $\mathbb{E}[\boldsymbol{\varepsilon} | \mathbf{X}] = \mathbf{0}$ 且 $\text{Cov}(\boldsymbol{\varepsilon} | \mathbf{X}) = \sigma^2 \mathbf{I}_n$ 。普通最小二乘估计量为

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}.$$

它在给定 $\mathbf{X}$ 时无偏, 并且

$$\text{Var}(\mathbf{a}^\top \hat{\boldsymbol{\beta}} | \mathbf{X}) = \sigma^2 \mathbf{a}^\top (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{a}.$$

因此新增观测的特征方向会改变设计矩阵，并降低某些 $\mathbf{a}$ 方向的方差；它未必同样改善其他方向、预测总体或非线性目标。最小化最坏方向、平均方向或行列式体积会得到不同设计准则，必须先声明评价对象。

当标注预算有限时，主动学习 (active learning) 根据当前模型选择下一批待标注样本。若效用 U 已经包含任务收益与查询成本，一个理想选择可写成最大化期望效用增量：

$$\mathbf{x}^* \in \arg \max_x \mathbb{E}_{Y|x, \mathcal{D}} [U(\mathcal{D} \cup \{(\mathbf{x}, Y)\}) - U(\mathcal{D})],$$

其中 U 衡量后验不确定性减少或决策效用增加。只选当前最不确定样本是一种替代规则，不一定等于任务价值最大。若把效用设为后验熵的负值， $U(\mathcal{D}) = -H(\Theta | \mathcal{D})$ ，则期望效用增量就是预期熵下降，才与第 11 章定义的互信息相对应；若改按决策风险评价，记

$$r(\mathcal{D}) = \inf_a \mathbb{E}[\ell(\mathbf{a}, \Theta) | \mathcal{D}], \quad U(\mathcal{D}) = -r(\mathcal{D}).$$

这里取有限的最优风险并使用其负值作效用，期望增量才是风险的下降：

$$r(\mathcal{D}) - \mathbb{E}_{Y|x, \mathcal{D}} r(\mathcal{D} \cup \{(\mathbf{x}, Y)\}).$$

若一次查询还有成本，就从这项下降中扣除该成本，不再重复计入效用。这就是第 15.4.4 节按风险下降定义的信息价值。信息量增加与任务效用增加不是同一命题。

主动选择会改变被标注样本的分布。若候选池不覆盖目标总体，算法无法询问缺失区域；若标注噪声随难度变化，不确定样本还可能最不可靠；若最终指标用同一批自适应选择数据计算，评价也会偏移。因此应在比较前固定可访问数据、查询成本、标注机制和独立评价集。查询依赖过去答案时，所选特征或对象必须在新噪声揭示前由历史信息确定，才能回用第 10.4.5.3 节的可预测设计与自适应误差工具；把自适应记录事后当作固定独立样本没有同样保证。实验设计不是分析完成后的附注，而是可识别性和误差保证的一部分。

10.6 本章小结

回到传感器问题：随机变量是读数规则，一次读数是它的实现值，分布是该规则在指定概率下的取值规律。两台设备的边缘误差相同，不保证平均误差相同；联合分布、条件信息和独立性决定能使用哪些组合公式。函数变换、条件随机生成和概率加权分别改变取值、生成规则及基础权重，不能只看输出形式来区分。

重复观测带来两类结论。集中界在给定样本量下控制误差，大数和中心极限定理分别描述平均位置与缩放波动的长期行为。时间过程还要求区分时刻分布与路径、条件均值与条件分布、不变性与趋于不变分布。Poisson 跳跃经过补偿仍有跳跃；布朗路径连续却几乎必然处处不可微，非零二次变差将成为随机积分的重要输入。

规律未知时，先检查数据是怎样收集的，以及目标能否由观测分布确定，再选择估计方法。估计均值的误差与预测下一次读数的误差不同，后者还包含新读数自身的噪声。置信区间、可信区间和预测集合分别依据重复抽样、参数后验和未来观测解释覆盖；只保证固定时刻有效的程序，也不能直接用于任意停止。本章的计算都依赖明确的可积性、取值范围、抽样、依赖或正则条件。后续信息比较、因果推断及随机状态演化会继续使用这些工具，但仍须根据各自的新问题重新明确目标和假设。

随机分布

记录一串随机结果时，常见结果可以用短码，罕见结果需要较长描述。预测这些结果时，给真实结果分配过小的概率又会增加描述代价。这两个问题都涉及概率，却不相同：前者问一个规律本身有多少不确定性，后者问用另一个规律代替它会付出多少代价。若预测的是温度，还会出现第三个问题：整体偏移 0.1 度与把少量概率移到极端温度，对平均误差和越界概率的影响是否相同？

本章沿着这些问题展开：先计算描述随机结果需要多少信息，再比较两种分布的差异，检查差异怎样影响预测任务，最后讨论怎样选择和优化分布。第 10 章已经建立随机变量的分布、条件化和换测度；这里通常把分布 P 固定下来研究。“随机分布”指随机变量的概率规律，不表示 P 自身必然随机。若算法根据样本返回一张分布，则另外说明样本随机性，并使用前章随机概率测度的定义。

参数相近也不能替代分布相近。高斯均值移动相同距离，在噪声较小时更容易被辨认；即使分布不变，仅改用均值的立方根作为参数，也会改变参数之间的欧氏距离。因而先要确定比较什么，才能判断一个小差异是否足以保护任务结果，或怎样约束一次参数更新。除编码处显式使用 $\log_2$ 外，本章的 $\log$ 均为自然对数，单位为 nat；以二为底时单位为 bit， $1 \text{ bit} = (\log 2) \text{ nat}$ 。

11.1 随机分布的信息量

压缩一张已知分布产生的记录，需要把每个结果的描述长度与出现频率配合起来。如果发送者和接收者已经知道部分信息，就只需描述剩余部分；能省多少，取决于已知信息与待描述结果的关系。离散结果可以直接分配码字，连续结果则必须先选定记录精度或参考测度，才能明确所计算的信息量。

11.1.1 离散分布的信息量

11.1.1.1 无条件结果的平均信息

例如，记录两次独立抽样的结果，联合概率是两次概率的乘积，描述长度却应是两次长度之和。因此采用负对数可以把独立概率的相乘转化为描述长度的相加。设结果 x 的发生概率为 $p(x) > 0$ 。自信息 (self-information) $-\log p(x)$ 表示看到这次结果时的意外程度：概率越小，数值越大。它是单次结果的量，尚未对所有可能结果平均。

定义 11.1 离散熵 设离散随机变量 X 取值于有限或可数字母表 $\mathcal{X}$ ，质量函数为 p 。其熵 (entropy) 是自信息的平均：

$$H(X) = - \sum_{x \in \mathcal{X}} p(x) \log p(x) = \mathbb{E}[-\log p(X)]. \quad (11.1)$$

约定 $0 \log 0 = 0$ 。这是非负扩展值求和，可以为 $+\infty$ 。熵有限的条件可写为

$$\sum_x p(x) |\log p(x)| < \infty.$$

常量没有待区分的结果，熵为零； m 个等概率结果的熵为 $\log m$ 。例如 $X \sim \text{Bernoulli}(1/4)$ 时，

$$H(X) = -\frac{1}{4} \log \frac{1}{4} - \frac{3}{4} \log \frac{3}{4} \approx 0.5623 \text{ nat} \approx 0.8113 \text{ bit}.$$

结果 1 的自信息为 2 bit，但它只占四分之一的发生概率，所以平均值不到一位。这个平均数能否真的变成码长，要同时检查码字能否解码。

二进制前缀码 (prefix code) 要求任何码字都不是另一个码字的前缀，因此串接后可以逐个解析。码字 0, 10, 11 满足这一要求，0, 01 则不满足。若码长为非负整数 $\ell(x)$ ，把长度为 ℓ 的码字看成二叉树深度 ℓ 的节点，它占据的后代比例是 $2^{-\ell}$ 。前缀码所占的后代不能重叠，故

$$\sum_x 2^{-\ell(x)} \leq 1.$$

这就是 Kraft 约束。理想实数码长 $-\log_2 p(x)$ 恰好使总和为一，实际码长则还要满足整数约束¹。

定理 11.2 无失真前缀码的平均长度界 对熵有限的质量函数 p ，任意满足 Kraft 约束的二进制码长均满足

$$\mathbb{E}\ell(X) \geq H(X)/\log 2.$$

¹ T. M. Cover, J. A. Thomas, *Elements of Information Theory*, Wiley, 2006, 2nd ed.

在有效字母表 $\mathcal{X}_+ = \{x : p(x) > 0\}$ 上, $\ell(x) = \lceil -\log_2 p(x) \rceil$ 可由前缀码实现, 并且

$$\mathbb{E}\ell(X) < H(X)/\log 2 + 1.$$

证明. 若平均码长无限, 下界直接成立。否则令 $K = \sum_x 2^{-\ell(x)} \in (0, 1]$, $q(x) = 2^{-\ell(x)}/K$ 。由 $-\log u \geq 1 - u$, 在 $p > 0$ 的点上求和得到

$$\sum_x p(x) \log \frac{p(x)}{q(x)} \geq 1 - \sum_{x: p(x) > 0} q(x) \geq 0.$$

所以

$$0 \leq -H(X) + (\log 2)\mathbb{E}\ell(X) + \log K.$$

因 $\log K \leq 0$, 移项即得下界。这里直接证明所需的对数不等式, 没有预先使用后文才定义的 KL。

对取整码长, $2^{-\ell(x)} \leq p(x)$, 故满足 Kraft 约束。按码长非降排列有效字母表, 依次在 $[0, 1)$ 放置长度 $2^{-\ell(x)}$ 的半开二进区间。此前区间长度都是当前长度的整数倍, 因此新左端点仍与当前二进网格对齐; 总长度不超过一, 区间都能放下。以左端点的前 $\ell(x)$ 个二进位为码字。若一个码字是另一个的前缀, 相应二进区间便会嵌套, 与区间互不相交矛盾。这个构造也适用于可数字母表, 因为每个有限码长下只能有有限个码字。再对 $[a] < a + 1$ 平均, 得到严格上界。 ■

Bernoulli 例子的两个有效结果都必须使用至少一位, 逐符号码长为 1 bit; 与 0.8113 bit 的差来自整数限制。对独立的 n 个结果一起编码, 块熵为 $nH(X)$, 每符号冗余可小于 $1/n$ bit。零质量符号已从有效字母表删除; 若也必须传输它们, 要额外留出码空间。只有一个有效符号时, 上述约定允许空码字, 并假定符号个数已知。允许重建失真则是另一任务, 码长还依赖失真准则, 不能仅由熵决定。

11.1.1.2 已有观测下的剩余信息

若发送者和接收者都知道 $Y = y$, 需要描述的是条件分布 $p(x | y)$, 而不是重新描述整个 X 。前章的条件分布使这一点可以逐个条件值计算。

定义 11.3 离散条件熵 对离散随机变量 X, Y , 在 $p(y) > 0$ 处令 $H(X | Y = y) = -\sum_x p(x | y) \log p(x | y)$ 。条件熵 (conditional entropy) 定义为这些剩余信息量的平均:

$$H(X | Y) = \sum_y p(y) H(X | Y = y) = -\sum_{x,y} p(x,y) \log p(x | y). \quad (11.2)$$

零质量条件值可以任意指定条件分布，贡献为零；结果允许为 $+\infty$ 。

在联合质量为正的点， $p(x, y) = p(y)p(x | y)$ 。对负对数取期望得到

$$\begin{aligned} H(X, Y) &= - \sum_{x, y} p(x, y) \log p(y) - \sum_{x, y} p(x, y) \log p(x | y) \\ &= H(Y) + H(X | Y). \end{aligned}$$

这些项非负，非负求和换序保证等式在扩展值意义下也成立。反复分解给出联合熵的链式法则：

$$H(X_1, \dots, X_n) = \sum_{i=1}^n H(X_i | X_1, \dots, X_{i-1}). \quad (11.3)$$

链式法则不要求独立；独立时各条件熵才可换成无条件熵。若要移项写成熵之差，必须确认相应熵有限，不能计算 $\infty - \infty$ 。

示例 11.4 一次带噪二元观测 令 X 在 $\{0, 1\}$ 上均匀，观测 $Y = X \oplus N$ ，其中 $\oplus$ 为异或， $N \sim \text{Bernoulli}(\varepsilon)$ 独立于 X ， $0 \leq \varepsilon \leq 1/2$ 。对每个 y ，

$$P(X = y | Y = y) = 1 - \varepsilon, \quad P(X = 1 - y | Y = y) = \varepsilon.$$

定义二元熵函数 $H_b(u) = -u \log u - (1 - u) \log(1 - u)$ ，端点沿用零项约定。于是 $H(X) = \log 2$ 、 $H(X | Y) = H_b(\varepsilon)$ 。当 $\varepsilon = 1/4$ 时，观测后剩余 0.5623 nat，比观测前少 0.1308 nat；无噪声时没有剩余不确定性，当 $\varepsilon = 1/2$ 、观测值等概率被保留或翻转时，仍剩全部 $\log 2$ nat。

这里计算的是观测后的平均剩余不确定性，不保证每次都能准确恢复原结果。观测平均消除的部分说明两个变量之间有多少信息依赖。第 11.2.2 节将用分布比较给出这个依赖量的一般定义，并展示上述例子中噪声增大时的信息变化。

11.1.2 连续分布的信息量

连续结果若要求无限精度，单次记录通常不能用有限比特无失真描述。可以先把实轴分成宽度 Δ 的小格；在密度足够规则时，格子概率近似 $p(x)\Delta$ ，格子编码熵便近似 $-\int p \log p - \log \Delta$ 。精度代价 $-\log \Delta$ 需要单独保留，余下的密度项才是微分熵。这个近似用来解释记录精度与密度信息的区别，并非对任意密度都成立的量化极限定理。

定义 11.5 微分熵 固定参考测度 μ 。若 $P \ll \mu$ 、 $p = dP/d\mu$ ，且 $\mathbb{E}_P |\log p(X)| < \infty$ ，定义相对于 μ 的熵

$$h_\mu(P) = - \int p \log p \, d\mu.$$

在 $\mathbb{R}^d$ 上取 Lebesgue 测度时，称为微分熵 (differential entropy)，简记为 $h(\mathbf{X})$ 。

指定参考测度是定义的一部分。若换成 $\mu' = a\mu$ ，其中 $a > 0$ ，密度变为 p/a ，故 $h_{\mu'}(P) = h_\mu(P) + \log a$ 。与离散质量不同，密度可能大于一，其负对数也可能为负。例如 X 在 $[0, 1/2]$ 上均匀时密度为 2， $h(X) = -\log 2$ 。这里的负值不表示可以使用负码长：微分熵只保留密度项，尚未加上记录精度的代价。

坐标变化有相同影响。设 $g : \mathbb{R}^d \rightarrow \mathbb{R}^d$ 为 C^1 微分同胚， $\mathbf{Y} = g(\mathbf{X})$ ，且 $\mathbb{E} |\log |\det \mathbf{J}_g(\mathbf{X})|| < \infty$ 。由前章密度换元公式， $p_Y(g(\mathbf{x})) = p_X(\mathbf{x})/|\det \mathbf{J}_g(\mathbf{x})|$ 。取负对数并按 $\mathbf{X}$ 平均，便得到

$$h(\mathbf{Y}) = h(\mathbf{X}) + \mathbb{E} \log |\det \mathbf{J}_g(\mathbf{X})|. \quad (11.4)$$

特别地，对可逆矩阵 $\mathbf{A}$ ， $h(\mathbf{A}\mathbf{X} + \mathbf{b}) = h(\mathbf{X}) + \log |\det \mathbf{A}|$ 。把长度从米改成厘米会增加 $\log 100$ ，尽管没有获得新的观测信息。因此微分熵不能单独充当坐标不变的分布差异；下一节比较两张密度时，共同的 Jacobian 因子会在比值中相消。

11.2 随机分布之间的关系

熵只评价一个规律。两个不同分布可以有相同熵，两个变量也可以分别具有相同边缘熵，却在一个模型中独立、另一个模型中完全相关。要辨认这些差别，需要明确比较对象。对数评分比较真实规律与预测规律，互信息比较联合规律与独立规律；比较事件概率、函数期望和结果位置，又会得到不同的差异。随后我们用这些差异判断两种模型能否被观测区分，并给出任何估计方法都无法突破的误差下界。

11.2.1 对数评分下的分布比较

仍然编码结果，但接收者现在只持有预测分布 Q ，真实结果却来自 P 。按 Q 分配的理想码长为 $-\log q(x)$ ；高概率真实结果若被 Q 低估，平均描述就会变长。对数损失 (log loss) 正是用这个代价评价概率预测。

定义 11.6 离散交叉熵 对同一离散空间上的质量函数 p, q , 交叉熵 (cross-entropy) 定义为

$$H(P, Q) = - \sum_x p(x) \log q(x). \quad (11.5)$$

零质量 $p(x) = 0$ 的项贡献为零; 若 $p(x) > 0$ 而 $q(x) = 0$, 则结果为 $+\infty$ 。

交叉熵不是 Q 自身的熵, 因为平均所用的概率仍是 P 。要知道多出的描述长度有多少, 需要从交叉熵中扣除真实分布自身的熵。前章的 Radon-Nikodym 导数使这种比较不依赖离散或连续表示。

定义 11.7 相对熵 同一可测空间上的概率测度 P, Q 若满足 $P \ll Q$, 令 $L = dP/dQ$ 。相对熵 (relative entropy), 也称 KL 散度, 定义为

$$D_{\text{KL}}(P||Q) = \int \log L \, dP = \int L \log L \, dQ. \quad (11.6)$$

若 $P \not\ll Q$, 约定为 $+\infty$, 并采用 $0 \log 0 = 0$ 。

负部积分总有限, 因为在 $0 \leq L \leq 1$ 上有 $0 \leq -L \log L \leq 1/e$ 。因此定义不会出现无穷减无穷; 有限性还要求正部可积, 绝对连续本身并不足够。在共同密度表示下, 积分为 $\int p \log(p/q) \, d\mu$ 。离散情形逐项分解得到

$$H(P, Q) = H(P) + D_{\text{KL}}(P||Q). \quad (11.7)$$

若 $H(P) < \infty$, 这说明真实分布固定时交叉熵的多余代价恰是 KL。若 $H(P) = +\infty$, 等式按扩展值理解: 所有预测分布的交叉熵都无限, 不能再用交叉熵的数值区分它们, 但直接定义的 KL 仍可能有限。

定理 11.8 Gibbs 不等式 任意概率测度 P, Q 满足 $D_{\text{KL}}(P||Q) \geq 0$, 且等号当且仅当 $P = Q$ 。

证明. 只需处理 $P \ll Q$ 。取共同支配测度 $\mu = P + Q$, 密度为 p, q , 在 $\{p > 0\}$ 上令 $r = q/p > 0$ 。由 $-\log r \geq 1 - r$,

$$D_{\text{KL}}(P||Q) \geq 1 - \mathbb{E}_P r = 1 - \int_{\{p>0\}} q \, d\mu \geq 0.$$

等号要求非负差 $-\log r - 1 + r$ 在 P -几乎处处为零, 即 $r = 1$, 并要求 Q 在 $\{p = 0\}$ 上没有额外质量, 所以 $P = Q$ 。反过来 $P = Q$ 时密度比为一, 积分为零。 ■

在真实熵有限的离散分布类上, 对数评分的期望只在真实分布处达到最小, 这称为严格适当性 (strict propriety): 若能报告任意分布, 如实报告真实概率会使期望对数损失最小。连续密度也可定义 $-\int p \log q$ 并作同一分解, 但必须先确认期望存在, 且真实密度的对数可积。有限样本的最小经验损失则是前章讨论的估计问题, 仍有模型限制、抽样偏差和求解误差, 不能由适当性直接推断拟合正确。

KL 的方向指定了谁来加权。取 $P = \text{Bernoulli}(0.9)$ 、 $Q = \text{Bernoulli}(0.6)$, 有

$$D_{\text{KL}}(P\|Q) \approx 0.2263, \quad D_{\text{KL}}(Q\|P) \approx 0.3112.$$

若 $Q(1) = 0 < P(1)$, 前向 KL 无限; 反向是否有限仍需检查反向支持。它也不是满足三角不等式的距离。令 P, Q, R 依次为参数 0.1, 0.2, 0.3 的 Bernoulli 分布, 则

$$D_{\text{KL}}(P\|R) \approx 0.1163 > D_{\text{KL}}(P\|Q) + D_{\text{KL}}(Q\|R) \approx 0.0624.$$

对 $P = \mathcal{N}(\mu, \sigma^2)$ 、 $Q = \mathcal{N}(\nu, \sigma^2)$, $\sigma > 0$, 对数密度比为 $\{(x - \nu)^2 - (x - \mu)^2\}/(2\sigma^2)$ 。按 P 平均时交叉项均值为零, 故

$$D_{\text{KL}}(P\|Q) = \frac{(\mu - \nu)^2}{2\sigma^2}. \quad (11.8)$$

同样, 对共同正定协方差 Σ 的向量高斯,

$$D_{\text{KL}}(\mathcal{N}(\mu, \Sigma)\|\mathcal{N}(\nu, \Sigma)) = \frac{1}{2}(\mu - \nu)^\top \Sigma^{-1}(\mu - \nu). \quad (11.9)$$

这个式子先用协方差逆矩阵调整各方向的尺度, 再比较均值位移。因此同样大小的位移, 沿低方差方向发生时更容易被辨认。若 Σ 只半正定, 两个仿射支持相同当且仅当 $\mu - \nu \in \text{range}(\Sigma)$ 。支持相同时可限制到该子空间并使用 $\Sigma^\dagger$; 否则两支持不相交, KL 无限。不能只替换成伪逆而忽略支持条件。

若对 P, Q 同时施加可测双射 g , 且逆映射可测, 则推送密度比为 $L \log^{-1}$, 所以 KL 保持不变。光滑换元时, 这就是两个 Jacobian 项相消。非可逆处理通常会丢失差异。若通过共同概率核 K 输出 Y , 在联合参考规律 $Q(dx)K(dy|x)$ 下有

$$\frac{d(PK)}{d(QK)}(Y) = \mathbb{E}_Q[L(X) | Y].$$

由 $u \log u$ 的凸性和条件 Jensen 不等式,

$$D_{\text{KL}}(PK\|QK) \leq \mathbb{E}_Q[L \log L] = D_{\text{KL}}(P\|Q).$$

这在扩展值意义下成立；不绝对连续时右侧无限，界仍成立。核可以是确定映射，也可以使用额外随机性，但必须对两个输入规律采用同一处理规则。

11.2.2 联合分布的信息依赖

前一小节固定真实分布，再与预测分布比较。现在固定一对变量的实际联合分布，将比较对象换成“保持各自边缘，却令它们独立”的分布。这样得到的量只反映联合关系，而不是各变量单独有多不确定。

11.2.2.1 无条件关系的互信息

定义 11.9 互信息 对具有联合分布 P_{XY} 的随机元素 X, Y ，互信息 (mutual information, MI) 定义为

$$I(X; Y) = D_{\text{KL}}(P_{XY} \| P_X \otimes P_Y). \quad (11.10)$$

定义适用于一般可测空间，允许值为 $+\infty$ ，不要求先存在密度或有限熵。

Gibbs 不等式给出非负性，而且 $I(X; Y) = 0$ 当且仅当 X, Y 独立。这强于零协方差：例如 X 在 $\{-1, 0, 1\}$ 上均匀， $Y = X^2$ ，协方差为零，但 Y 完全由 X 确定，互信息为 $H(Y) = H_b(1/3) > 0$ 。对可数离散变量，定义展开为 $\sum_{x,y} p(x,y) \log[p(x,y)/(p(x)p(y))]$ ；当 $H(X, Y) < \infty$ 时，展开对数并用熵链式法则可得

$$I(X; Y) = H(X) - H(X | Y) = H(Y) - H(Y | X). \quad (11.11)$$

所以互信息是观测平均消除的不确定性。连续变量在相关微分熵均有限时也可作相应分解，但 KL 定义更一般。例如连续的 $Y = X$ 可能使联合分布落在对角线上，相对于边缘乘积奇异，此时互信息无限，不能强行用有限密度公式计算。

回到例 11.4，有 $I(X; Y) = \log 2 - H_b(\varepsilon)$ 。图 11.1 中两条曲线相加始终为 $\log 2$ ；翻转噪声改变的是观测可提供的信息；输入仍等概率取 0, 1，其熵保持不变。由于对两个变量分别施加可逆变换会同时推送联合分布与边缘乘积，互信息继承 KL 的不变性。这与微分熵随坐标单位改变形成区别。

11.2.2.2 条件关系的互信息

已经知道 Z 时，应在同一个条件值下判断 X, Y 是否还有关系，再按 Z 的发生概率平均。不能把三者的边缘依赖随意相减。




图 11.1 均匀二元输入通过独立翻转通道后的信息分配（解析式教学图）。蓝实线为剩余条件熵 $H_b(\epsilon)$ ，红虚线为互信息 $\log 2 - H_b(\epsilon)$ ，均以 nat 计。输入熵保持不变；无噪声时观测保留完整信息，以 $1/2$ 概率翻转时观测不提供信息。

定义 11.10 条件互信息 设 X, Y, Z 取值于标准 Borel 空间，因而存在所需正则条件分布。条件互信息（conditional mutual information）定义为

$$I(X; Y | Z) = \int D_{\text{KL}}(P_{XY|Z} \| P_{X|Z} \otimes P_{Y|Z}) P_Z(dz). \quad (11.12)$$

条件核的版本只需在 P_Z -几乎处处确定；被积量非负，允许结果为 $+\infty$ 。

在不保证正则条件分布存在的一般空间上，不能不加条件地沿用这个条件核定义。在上述条件下，零条件互信息等价于条件联合核几乎处处等于条件边缘乘积，也就是前章的条件独立。有限熵时可写成 $H(X | Z) - H(X | Y, Z)$ ；一般情形应使用非负 KL 积分，以避免无穷相减。

条件化并不一定使互信息变小。取独立均匀二元变量 X, Y ，令 $Z = X \oplus Y$ 。边缘上互信息为零；固定 Z 后， X 完全决定 Y ，条件互信息为 $\log 2$ 。反过来，若 $X = Y = Z$ 为同一个均匀二元变量，无条件互信息为 $\log 2$ ，条件互信息却为零。前者揭示约束，后者去掉已经知道的共享信息。

后处理和序贯观测都要用到 KL 的条件分解。设联合规律 P_{AB}, Q_{AB} 满足相应绝对连续性，条件核存在。联合密度比分解为边缘比与条件比的乘积，取对数并用塔式性质得到

$$D_{\text{KL}}(P_{AB} \| Q_{AB}) = D_{\text{KL}}(P_A \| Q_A) + \mathbb{E}_{A \sim P_A} D_{\text{KL}}(P_{B|A} \| Q_{B|A}). \quad (11.13)$$

每个对数比的负部可积，故有限项相加的分解也能按非负扩展值成立；若绝对连续性失败，对应的条件或边缘项为无限。把 Q_{XYZ} 选为 $P_X \otimes P_{YZ}$ ，再按 (X, Y) 与 Z 分组，第一项是 $I(X; Y)$ ，条件项是 $\mathbb{E}_{X,Y} D_{\text{KL}}(P_{Z|X,Y} \| P_{Z|Y}) = I(X; Z | Y)$ 。因此

$$I(X; Y, Z) = I(X; Y) + I(X; Z | Y).$$

这证明了互信息链式法则，而不仅是引用熵差记号。

定理 11.11 数据处理不等式 若标准 Borel 随机元素满足 Markov 关系 $X \rightarrow Y \rightarrow Z$ ，即 $X \perp Z | Y$ ，则 $I(X; Z) \leq I(X; Y)$ ，允许扩展值。

证明. 用两种顺序分解同一联合信息量：

$$I(X; Y, Z) = I(X; Y) + I(X; Z | Y) = I(X; Y),$$

$$I(X; Y, Z) = I(X; Z) + I(X; Y | Z) \geq I(X; Z).$$

第一行的条件项由条件独立为零，第二行的条件项非负，合并即得。证明只作非负项的相加和比较，不需要有限熵，也没有无穷相减。 ■

处理可以是 $Z = g(Y)$ ，也可以是仅依赖 Y 的随机通道。若额外随机性还与 X 关联，Markov 前提可能不成立。信息不增加并不保证每个任务的误差严格增加；当丢弃的内容与任务无关时可以取等号。

11.2.3 分布差异的比较尺度

预测评分关心对数代价，越界报警关心事件概率，温度误差还关心数值相距多远。这些要求需要比较不同的量。下面分别控制事件概率、函数期望和质量移动距离，说明每种比较能回答什么问题。不同方法也可能重合，例如某些搬运距离可以写成一类函数期望差的上确界。

11.2.3.1 概率权重的差异

报警规则由一个事件 A 指定。若尚未决定具体规则，可以问所有事件中，哪一个的发生概率改变最多。

定义 11.12 总变差距离 同一可测空间上概率测度的总变差距离 (total variation distance, TV) 为

$$d_{\text{TV}}(P, Q) = \sup_A |P(A) - Q(A)|, \quad (11.14)$$

其中上确界遍历全部可测事件。

取共同支配测度 μ , 密度为 p, q 。由于 $\int (p - q) d\mu = 0$, 正部与负部积分相等。任意事件上的差不超过正部积分, 而 $A^* = \{p \geq q\}$ 达到该值, 所以

$$d_{TV}(P, Q) = \frac{1}{2} \int |p - q| d\mu = P(A^*) - Q(A^*). \quad (11.15)$$

对 $|f| \leq 1$, 积分的绝对值不超过 $\int |p - q|$; 取 $f = 2\mathbb{1}_{A^*} - 1$ 达到上界, 故

$$2d_{TV}(P, Q) = \sup_{\|f\|_\infty \leq 1} |\mathbb{E}_P f - \mathbb{E}_Q f|. \quad (11.16)$$

若 $0 \leq f \leq 1$, 令 $g = 2f - 1$, 相应上确界则恰为 d_{TV} 。事件指标给出取等号的函数。这两个常数的差别来自值域宽度, 不是定义冲突。

若希望用熟悉的函数空间距离来比较密度, 可以先把密度开平方。由于密度积分为一, 平方根密度的 L^2 范数也为一; 于是两个分布可以作为单位球面上的两个函数来比较。

定义 11.13 Hellinger 距离 在共同支配测度 μ 下, 定义平方 Hellinger 距离为

$$d_H^2(P, Q) = \frac{1}{2} \int (\sqrt{p} - \sqrt{q})^2 d\mu = 1 - \int \sqrt{pq} d\mu, \quad (11.17)$$

距离本身为其非负平方根。

更换共同支配测度时, 两个平方根都乘以同一密度因子的平方根, 积分换元后不变。对三个分布可统一使用其和作支配测度, 从 L^2 三角不等式得到 d_H 的三角不等式。利用 $|p - q| = |\sqrt{p} - \sqrt{q}|(\sqrt{p} + \sqrt{q})$, 有

$$d_H^2(P, Q) \leq d_{TV}(P, Q) \leq \sqrt{2} d_H(P, Q).$$

左侧用 $\sqrt{p} + \sqrt{q} \geq |\sqrt{p} - \sqrt{q}|$; 右侧用 Cauchy-Schwarz 以及 $\int (\sqrt{p} + \sqrt{q})^2 d\mu \leq 4$ 。

若已知两种预测规律的 KL 很小, 还能否保证它们对报警事件给出的概率接近? 下面的界把平均对数代价转成最坏事件概率差, 因此连接了 KL 与 TV 这两种比较。

定理 11.14 Pinsker 不等式 以自然对数定义 KL 时,

$$d_{TV}(P, Q) \leq \sqrt{\frac{1}{2} D_{KL}(P \| Q)}. \quad (11.18)$$

证明. KL 无限时无需证明; 否则 $P \ll Q$ 。令 $A = \{dP/dQ \geq 1\}$ 、 $a = P(A)$ 、 $b = Q(A)$, 则 $a - b = d_{TV}(P, Q)$ 。在 A 及其补集分别对密度比使用条件 Jensen 不等式, 得到

$$D_{KL}(P||Q) \geq a \log \frac{a}{b} + (1-a) \log \frac{1-a}{1-b}.$$

固定 $b \in (0, 1)$, 右侧作为 a 的函数在 $a = b$ 处值和一阶导数为零, 二阶导数为 $1/[a(1-a)] \geq 4$ 。Taylor 积分余项给出至少 $2(a-b)^2$ 。端点通过连续延拓处理; 若 $b = 0$ 或 1 , 有限 KL 迫使相应 $a = b$ 。整理即得结论。 ■

取 $P = \text{Bernoulli}(1/4)$ 、 $Q = \text{Bernoulli}(1/2)$, 则

$$d_{TV} = \frac{1}{4}, \quad d_H^2 \approx 0.0341, \quad D_{KL}(P||Q) \approx 0.1308.$$

Pinsker 给出的上界约为 0.2557。总变差很小却不能反过来保证 KL 有限: $P = (1-\eta)\delta_0 + \eta\delta_1$ 、 $Q = \delta_0$ 的总变差只有 η , 但只要 $\eta > 0$, 前向 KL 就无限。

KL 记录对数密度比的平均值, 但有些罕见事件会被少数很大的密度比显著放大。要限制这种放大, 可以直接控制密度比的高阶矩。

定义 11.15 高于一阶的 Rényi 散度 对 $\alpha > 1$ 及 $P \ll Q$, Rényi 散度定义为

$$D_\alpha(P||Q) = \frac{1}{\alpha-1} \log \mathbb{E}_Q \left[\left(\frac{dP}{dQ} \right)^\alpha \right]. \quad (11.19)$$

若绝对连续性失败或该阶矩无限, 结果为 $+\infty$ 。

令 $L = dP/dQ$, Jensen 给出 $\mathbb{E}_Q L^\alpha \geq (\mathbb{E}_Q L)^\alpha = 1$, 故散度非负。为了比较不同阶数, 需要把定理 6.4 的有限坐标配对推广到函数积分。若 $1 \leq p, q \leq \infty$ 、 $1/p + 1/q = 1$, 且相应范数有限, 则

$$\int |uv| d\mu \leq \|u\|_{L^p(\mu)} \|v\|_{L^q(\mu)}. \quad (11.20)$$

这就是积分形式的 Hölder 不等式。对 $1 < p, q < \infty$, 当两个范数非零时, 将 $|u|$ 、 $|v|$ 分别除以自己的范数, 再逐点使用上述定理证明中的 Young 不等式并积分; 右侧归一化后为 $1/p + 1/q = 1$, 恢复尺度即得本式。范数为零时相应函数几乎处处为零; 端点 $p = 1, q = \infty$ 直接用 $|v| \leq \|v\|_{L^\infty}$ 几乎处处成立, 另一端点交换两者。

取有限矩对应的 $a, b \geq 1$ 与 $0 < t < 1$, 对 $u = L^{ta}$ 、 $v = L^{(1-t)b}$ 使用指数 $p = 1/t$ 、 $q = 1/(1-t)$, 得到

$$\mathbb{E}_Q L^{ta+(1-t)b} \leq (\mathbb{E}_Q L^a)^t (\mathbb{E}_Q L^b)^{1-t}.$$

取对数便说明 $K(\alpha) = \log \mathbb{E}_Q L^\alpha$ 在有限区间上为凸函数；连同无穷值约定，它是扩展实值凸函数。又因 $K(1) = 0$ ，割线斜率 $K(\alpha)/(\alpha - 1)$ 随阶数不减。若某个 $\alpha_0 > 1$ 的阶矩有限，则从右侧趋于一时可对矩函数求导，得到 $D_\alpha \rightarrow \mathbb{E}_Q L \log L = D_{\text{KL}}$ 。更大的阶数更强调大密度比，而不是更大的空间位移。对上述 Bernoulli 例， $\mathbb{E}_Q L^2 = 1.25$ ，所以 $D_2 = \log 1.25 \approx 0.2231$ ，高于 KL。事件迁移将在第 11.3.1.1 节使用这一阶矩；重复机制的组合需要另外检查独立性或条件界。

11.2.3.2 测试函数的期望差异

如果任务只计算指定的一类函数，控制所有可测事件可能超出需要。可以把每个允许的测试函数当作一种观测，再比较它在两个分布下的平均读数。

定义 11.16 积分概率度量 给定非空实值可测函数类 $\mathcal{F}$ ，并假设每个成员在 P, Q 下可积，相应的积分概率度量 (integral probability metric, IPM) 为

$$d_{\mathcal{F}}(P, Q) = \sup_{f \in \mathcal{F}} |\mathbb{E}_P f - \mathbb{E}_Q f|. \quad (11.21)$$

它对称并满足三角不等式，但可能为无限；如果函数类不能区分分布，零值也可能对应不同分布，因而只给出伪距离。选择 $\|f\|_\infty \leq 1$ 得到两倍 TV。若选择核空间中范数不超过一的函数，期望比较就可以借助再生性质来计算：用一个核均值表示分布对这类函数的全部期望，再比较两个核均值。下面的 MMD 采用这一做法。

定义 11.17 最大均值差异 设 $\mathcal{H}$ 为再生核 Hilbert 空间，核 k 可测，且

$$\mathbb{E}_P \sqrt{k(X, X)} < \infty, \quad \mathbb{E}_Q \sqrt{k(Y, Y)} < \infty.$$

最大均值差异 (maximum mean discrepancy, MMD) 定义为

$$\text{MMD}(P, Q) = \sup_{\|f\|_{\mathcal{H}} \leq 1} |\mathbb{E}_P f - \mathbb{E}_Q f|.$$

第 5 章的再生性质给出 $|f(x)| \leq \|f\|_{\mathcal{H}} \sqrt{k(x, x)}$ ，所以 $f \mapsto \mathbb{E}_P f$ 是有界线性泛函。Riesz 表示定理保证存在唯一代表元 $\mu_P \in \mathcal{H}$ ，使 $\mathbb{E}_P f = \langle f, \mu_P \rangle_{\mathcal{H}}$ 。这就是核均值 (kernel mean embedding)。它用一个 Hilbert 空间元素同时表示该分布对空间中所有函数的期望：与任意 f 作内积，便得到 $\mathbb{E}_P f$ 。不

必预先假定 Hilbert 值积分存在；记号 $\mathbb{E}_P k(X, \cdot)$ 可由这个代表元解释。对 Q 同理，于是

$$\text{MMD}(P, Q) = \sup_{\|f\|_{\mathcal{H}} \leq 1} |\langle f, \mu_P - \mu_Q \rangle| = \|\mu_P - \mu_Q\|_{\mathcal{H}}.$$

差非零时取其归一化方向达到上确界。对可测有界核，所需可积条件自动满足。

如果两个分布的 MMD 为零，它们一定相同吗？只有核空间中的函数足以区分所研究的全部分布时，答案才是肯定的。

定义 11.18 核的特征性 在核均值均存在的指定分布类 $\mathcal{P}$ 上，若 $\mu_P = \mu_Q$ 蕴含 $P = Q$ ，即核均值映射为单射，则称核 k 在 $\mathcal{P}$ 上具有特征性 (characteristic)。

零 MMD 能否推出同分布，取决于这个条件。取同一对分布 $P = \delta_0$ 、 $Q = (\delta_{-1} + \delta_1)/2$ 。线性核 $k(x, y) = xy$ 只比较普通均值，故 MMD 为零，但 $P(\{0\}) = 1$ 、 $Q(\{0\}) = 0$ 。改用高斯核 $k(x, y) = e^{-(x-y)^2/2}$ ，展开核均值范数并用独立副本可得

$$\begin{aligned} \text{MMD}^2(P, Q) &= \mathbb{E}_{P \otimes P} k + \mathbb{E}_{Q \otimes Q} k - 2\mathbb{E}_{P \otimes Q} k \\ &= \frac{3}{2} + \frac{1}{2}e^{-2} - 2e^{-1/2} > 0. \end{aligned}$$

矩条件通过 $|k(x, y)| \leq \sqrt{k(x, x)k(y, y)}$ 保证展开中的积分可交换。图 11.2 固定这两个分布，只改变核。该算例证明高斯核能区分这一对对象，不代替整个分布类上的特征性证明。




图 11.2 同均值分布在不同核下的 MMD (解析式教学图)。左图为 $P = \delta_0$ 与 $Q = (\delta_{-1} + \delta_1)/2$ ，右图按精确总体期望计算：线性核给出零，高斯核给出约 0.595。没有使用有限样本估计；差别来自测试函数类。

11.2.3.3 质量位置的搬运差异

相邻两个点质量完全不重叠, TV 已达到一, KL 无限; 但若结果只是温度读数, 把全部质量移动 0.01 度仍应属于小变化。需要把样本空间的位置关系纳入比较。最优传输 (optimal transport, OT) 寻找保持两边概率不变的最便宜配对²。

² C. Villani, *Optimal Transport: Old and New*, Springer, 2009

定义 11.19 耦合 给定 $(X, \mathcal{A})$ 、 $(Y, \mathcal{B})$ 上的概率测度 P, Q , 其耦合 (coupling) 是乘积空间上的概率测度 γ , 满足

$$\gamma(A \times Y) = P(A), \quad \gamma(X \times B) = Q(B).$$

全体耦合记为 $\Pi(P, Q)$ 。

耦合规定来源位置与目标位置怎样联合配对, 同时保持来源分布和目标分布各自不变。独立耦合 $P \otimes Q$ 总存在, 但不一定便宜。给定非负可测成本 $c(x, y)$, Kantorovich 搬运代价为

$$\mathcal{T}_c(P, Q) = \inf_{\gamma \in \Pi(P, Q)} \int c(x, y) d\gamma(x, y). \quad (11.22)$$

下确界能否达到及怎样求解留到第 11.4.2 节。这里先把搬运用于比较分布。

定义 11.20 Wasserstein 距离 设 (X, d) 为完备可分度量空间, $1 \leq r < \infty$, 固定基点 x_0 并令

$$\mathcal{P}_r(X) = \left\{ P : \int d(x, x_0)^r dP(x) < \infty \right\}.$$

对 $P, Q \in \mathcal{P}_r(X)$, 定义

$$W_r(P, Q) = \left[\inf_{\gamma \in \Pi(P, Q)} \int d(x, y)^r d\gamma(x, y) \right]^{1/r}. \quad (11.23)$$

由 $d(x, x_1)^r \leq 2^{r-1}\{d(x, x_0)^r + d(x_0, x_1)^r\}$, 矩条件不依赖基点; 同一不等式说明独立耦合的成本有限。对称性来自底层距离, 对角耦合给出 $W_r(P, P) = 0$ 。若 $W_r(P, Q) = 0$, 任意有界 L -Lipschitz 函数的期望差至多 $L(\mathbb{E}_\gamma d(X, Y)^r)^{1/r}$, 沿近最优耦合趋于零。用连续函数 $\max\{1 - kd(x, C), 0\}$ 逼近闭集 C 的指标, 得到所有闭集上 $P(C) = Q(C)$, 故 $P = Q$ 。

三角不等式需要先控制随机距离之和。对 $u, v \in L^r(\mu)$, 这里使用 Minkowski 不等式 $\|u + v\|_{L^r} \leq \|u\|_{L^r} + \|v\|_{L^r}$ 。它仍沿用有限维的证明:

$r = 1$ 直接对绝对值三角不等式积分; $1 < r < \infty$ 时, 先由 $|u + v|^r \leq 2^{r-1}(|u|^r + |v|^r)$ 确认 $u + v \in L^r$, 再写

$$\|u + v\|_{L^r}^r \leq \int |u + v|^{r-1}(|u| + |v|) d\mu \leq \|u + v\|_{L^r}^{r-1}(\|u\|_{L^r} + \|v\|_{L^r}).$$

末步对两项分别使用式 (11.20), 指数为 $r/(r-1)$ 与 r 。非零时约去公共幂, 零时结论直接成立。

还需把两个配对接起来。把 P, Q 的耦合分解为 $P(dx | y)Q(dy)$, 把 Q, R 的耦合分解为 $Q(dy)R(dz | y)$ 。Polish 空间上的正则条件分布允许构造

$$P(dx | y)Q(dy)R(dz | y),$$

其相邻边缘正是原来的两张耦合。这是粘合引理在这里的具体实现。由 $d(X, Z) \leq d(X, Y) + d(Y, Z)$ 及 Minkowski 不等式,

$$(\mathbb{E}d(X, Z)^r)^{1/r} \leq (\mathbb{E}d(X, Y)^r)^{1/r} + (\mathbb{E}d(Y, Z)^r)^{1/r}.$$

分别选近最优耦合并令误差趋零, 就得到 $W_r(P, R) \leq W_r(P, Q) + W_r(Q, R)$ 。一般成本 c 不具备这些距离性质, $\mathcal{T}_c$ 不能自动称为距离; 超出矩条件时, 扩展定义还可能为无限。

对有限一阶矩的 P, Q , Kantorovich–Rubinstein 对偶给出

$$W_1(P, Q) = \sup_{\text{Lip}(f) \leq 1} |\mathbb{E}_P f - \mathbb{E}_Q f|. \quad (11.24)$$

其中 $\text{Lip}(f) \leq 1$ 表示 $|f(x) - f(y)| \leq d(x, y)$ 。可以固定 $f(x_0) = 0$, 不变期望差, 且一阶矩保证可积。任意耦合都给出右侧不超过左侧; 反向是最优传输对偶定理的实质内容, 这里按上述 Polish 及矩条件使用。有限空间的完整线性规划对偶将在后文推导。这说明 W_1 也是 IPM; $r > 1$ 的 W_r 没有这里同一个 Lipschitz 单位球表达。

用同方差高斯来比较三种尺度。令 $P = \mathcal{N}(\mu, \sigma^2)$ 、 $Q = \mathcal{N}(\nu, \sigma^2)$ 。取 $Y = X + \nu - \mu$ 得到恒定位移耦合, 而任意耦合满足 $\mathbb{E}|X - Y|^2 \geq |\mathbb{E}X - \mathbb{E}Y|^2 = |\mu - \nu|^2$, 故

$$W_2(P, Q) = |\mu - \nu|. \quad (11.25)$$

若 $\mu < \nu$, 两密度在 $c = (\mu + \nu)/2$ 相交, P 在 $(-\infty, c]$ 上的密度较大。因此

$$d_{\text{TV}}(P, Q) = P((-\infty, c]) - Q((-\infty, c]) = 2\Phi\left(\frac{|\mu - \nu|}{2\sigma}\right) - 1.$$

当 $|\mu - \nu| = 0.2, \sigma = 1$ 时, $W_2 = 0.2$ 、KL 为 0.02、TV 约为 0.0797。若标准差 σ 减半, 搬运位移不变, KL 增为 0.08, TV 也增大。位置差与可辨别程度因此不能互换。

图 11.3 保留同一位置族的三尺度对照，面板纵轴不同，不能按曲线高度判断哪一种概念更强。




图 11.3 同方差高斯位置族的解析式比较。固定 $P = \mathcal{N}(0, 1)$ 、 $Q = \mathcal{N}(h, 1)$ ，三图分别为 $D_{\text{KL}} = h^2/2$ 、 $d_{\text{TV}} = 2\Phi(h/2) - 1$ 与 $W_2 = h$ ，图中 $h \geq 0$ 。纵轴分别表达对数代价、事件概率差与搬运位移。

对点质量 $\delta_0, \delta_\varepsilon$ ，只要 $\varepsilon \neq 0$ ，TV 恒为一、两个方向 KL 均无限，而 $W_r = |\varepsilon| \rightarrow 0$ 。同一个点质量的移动，在 TV 和 KL 下始终差异很大，在 Wasserstein 距离下却随位移趋于零。这说明必须根据任务选择比较方式。对时间边缘分布 (P_t) 也可比较这些距离，但它们不决定轨迹机制：每时刻都为同一均匀二元分布，既可能来自反复独立抽样，也可能来自把初次抽样永远复制。两过程边缘距离为零，时间依赖却完全不同，必须比较联合轨迹。从样本估计 MMD 或 Wasserstein，还要说明所用核、搬运成本、矩条件和样本量。在高维空间中，经验分布的搬运距离可能有很大的估计误差；即使总体公式很简洁，样本估计也未必准确或容易计算。

11.2.4 观测分布的可区分性

分布差异也能说明推断的限度。若两个环境几乎产生相同观测，却要求不同答案，任何程序都不能同时在两者上准确。这里固定所要恢复的目标和数据收集方式，对所有估计程序给出下界；程序是否易于计算是另一问题。

11.2.4.1 固定观测下的区分限制

先把整批观测的分布视为已给定，不让程序根据中途结果改变取样位置。只有两个候选时，TV 直接给出区分错误；候选很多时，还要比较识别全部候选所需的信息与观测实际提供的信息。

两个候选的区分下界 设观测 Z 来自 P_0 或 P_1 , 先验各为 $1/2$ 。检验 $\psi(Z) \in \{0, 1\}$ 以事件 $A = \{\psi = 1\}$ 选择第二个候选, 则错误和为

$$P_0(A) + P_1(A^c) = 1 - \{P_1(A) - P_0(A)\}.$$

取使密度差为正的事件达到上确界, 得到

$$\inf_{\psi} \{P_0(\psi = 1) + P_1(\psi = 0)\} = 1 - d_{\text{TV}}(P_0, P_1). \quad (11.26)$$

随机化检验只是把指标改为 $[0, 1]$ 值函数, 按 TV 的函数表达也不能降低这个值。在等先验下, 最小总体错误是右侧的一半; 两类条件错误之和本身不是总体错误。

数值估计可以转成检验: 若估计足够准, 就应能知道它靠近哪个候选目标。

定理 11.21 Le Cam 两点下界 设观测模型 P_0, P_1 对应目标 θ_0, θ_1 , 在目标空间度量 d 下有 $d(\theta_0, \theta_1) \geq 2s$, $s > 0$ 。任意估计量 $\hat{\theta}$ 均满足

$$\max_{j \in \{0, 1\}} P_j\{d(\hat{\theta}, \theta_j) \geq s\} \geq \frac{1 - d_{\text{TV}}(P_0, P_1)}{2}. \quad (11.27)$$

证明. 构造最近目标检验 $\psi = \mathbb{I}\{d(\hat{\theta}, \theta_1) < d(\hat{\theta}, \theta_0)\}$, 距离相等时选 0。若真实为 0 且估计误差小于 s , 由三角不等式, 估计与 θ_1 的距离大于 s , 检验不会错。真实为 1 时同理。因此检验错误分别包含在估计坏事件内。两个坏事件概率之和至少为 $1 - d_{\text{TV}}(P_0, P_1)$, 其中最大者至少为一半, 即得结论。 ■

若每个候选下都得到 n 个独立同分布观测, 联合密度比是单次密度比的乘积, 取对数并平均得到 $D_{\text{KL}}(P_0^{\otimes n} \| P_1^{\otimes n}) = nD_{\text{KL}}(P_0 \| P_1)$ 。取单次规律为 $\mathcal{N}(-a, \sigma^2)$ 与 $\mathcal{N}(a, \sigma^2)$, 目标均值相距 $2a$, 整批 KL 为 $2na^2/\sigma^2$ 。令 $a = \sigma/(2\sqrt{n})$, KL 为 $1/2$, Pinsker 给出 TV 至多 $1/2$ 。所以任何均值估计量都至少在一个候选下, 以不小于 $1/4$ 的概率产生不小于 $\sigma/(2\sqrt{n})$ 的绝对误差。若评价平方误差, 还可由这个事件下界得到最坏风险至少 $\sigma^2/(16n)$ 。这些常数来自所选两点及放缩, 不声称最优。

多个候选的区分下界 两点只要求区分一个二元选择; 高维问题可能同时包含许多不同目标。令 V 在 $\{1, \dots, M\}$ 上均匀, 给定 $V = v$ 后观测 $Z \sim P_v$ 。解码器 $\hat{V}(Z)$ 的错误概率记为 p_e 。即使 Z 连续, V 的条件熵仍可按其有限后验概率求熵, 再对 Z 积分。

定理 11.22 Fano 不等式 对 $M \geq 2$ 及上述观测模型,

$$p_e \geq 1 - \frac{I(V; Z) + \log 2}{\log M}. \quad (11.28)$$

证明. 令 $E = \{\hat{V} \neq V\}$. 给定 Z 且 $E = 0$ 时, $V = \hat{V}(Z)$ 已确定; 给定 $E = 1$ 时, 至多还有 $M - 1$ 个可能索引. 有限字母表上最大熵为均匀熵, 这也可由与均匀分布的 Gibbs 不等式得到. 于是

$$\begin{aligned} H(V | Z) &\leq H(V, E | Z) \\ &= H(E | Z) + H(V | E, Z) \\ &\leq \log 2 + p_e \log(M - 1) \leq \log 2 + p_e \log M. \end{aligned}$$

又因 $H(V) = \log M$, 互信息分解给出 $H(V | Z) = \log M - I(V; Z)$. 移项得到结论. 随机化解码可把独立随机种子并入 Z , 不会增加关于 V 的信息. ■

若目标集中有两两距离至少 $2s$ 的有限分离集 $\{\theta_1, \dots, \theta_M\}$, 误差小于 s 就能最近邻解码. 这把前面计数与打包的工具接到统计下界: 候选多能提高 $\log M$, 但必须同时控制观测中含有多少索引信息³. 令 $\bar{P} = M^{-1} \sum_u P_u$, 则

$$I(V; Z) = \frac{1}{M} \sum_v D_{\text{KL}}(P_v \| \bar{P}) \leq \frac{1}{M^2} \sum_{v,u} D_{\text{KL}}(P_v \| P_u).$$

等式来自给定 V 的条件 KL 分解; 不等式来自 $-\log(M^{-1} \sum_u p_u) \leq M^{-1} \sum_u (-\log p_u)$. 因此 $\max_v P_v \{d(\hat{\theta}, \theta_v) \geq s\}$ 至少为 Fano 右侧, 若右侧为负则只得到平凡下界零.

下面用四个候选具体计算这个下界: 均值为 $\{-3a, -a, a, 3a\}$, 每个候选产生 n 个方差 σ^2 的独立高斯观测. 最小间距为 $2a$, 有序候选对的平均平方距离为 $10a^2$, 故

$$I(V; Z) \leq \frac{5na^2}{\sigma^2}.$$

取 $a = \sigma/(4\sqrt{n})$ 时右侧为 $5/16$, Fano 给出 $p_e \geq 1 - (5/16 + \log 2)/\log 4 \approx 0.2746$. 任意估计器因此至少在一个候选上以这一概率产生不小于 a 的误差. 目标分离与观测接近必须同时成立; 只罗列许多模型不构成下界证明.

11.2.4.2 序贯观测下的区分限制

若观测位置根据已获得的结果改变, 最终资料的联合分布也随算法改变. 仍可使用前面的检验不等式, 但比较对象应当是包含行动与结果的完整轨迹.

³ T. M. Cover, J. A. Thomas, *Elements of Information Theory*, Wiley, 2006, 2nd ed.

重复与时序观测的信息累积 独立重复是简单情形。设对应分量满足绝对连续性，密度比为 L_t 。乘积规律的比值为 $\prod_t L_t$ ，因此

$$\begin{aligned} D_{\text{KL}}\left(\bigotimes_t P_t \parallel \bigotimes_t Q_t\right) &= \sum_t D_{\text{KL}}(P_t \parallel Q_t), \\ D_\alpha\left(\bigotimes_t P_t \parallel \bigotimes_t Q_t\right) &= \sum_t D_\alpha(P_t \parallel Q_t), \quad \alpha > 1. \end{aligned}$$

第一式由对数把乘积化为和；第二式由独立性使 $\mathbb{E}_{\otimes Q_t} \prod_t L_t^\alpha = \prod_t \mathbb{E}_{Q_t} L_t^\alpha$ 。公式可按扩展值理解，不通过相减处理无限项。

一般序列不独立。设 $Z_{0:T}$ 在标准 Borel 空间取值，两个规律分解为初始分布及历史条件核， $P_0 \ll Q_0$ ，且在相关的 P -历史上 $P_t(\cdot \mid Z_{<t}) \ll Q_t(\cdot \mid Z_{<t})$ 。前章条件换测度给出联合密度比

$$L_{0:T} = L_0(Z_0) \prod_{t=1}^T L_t(Z_t \mid Z_{<t}).$$

对数相加，再对每一项先按历史条件平均，得到

$$\begin{aligned} D_{\text{KL}}(P_{0:T} \parallel Q_{0:T}) &= D_{\text{KL}}(P_0 \parallel Q_0) \\ &+ \sum_{t=1}^T \mathbb{E}_{Z_{<t} \sim P} D_{\text{KL}}(P_t(\cdot \mid Z_{<t}) \parallel Q_t(\cdot \mid Z_{<t})). \end{aligned} \quad (11.29)$$

这是式 (11.13) 的反复应用。有限时域中每个条件对数比的负部积分均有统一有限界，故可合法按扩展值累加；得到有限数值则还需累计条件 KL 有限。期望必须沿前向分布 P 实际产生的历史计算。

轨迹包含行动时，同一算法在同一历史上使用相同的条件行动核，所以比较两个环境时行动因子相消；两个环境的历史频率却不会相消。在同一环境比较两条策略时，则是环境核相消，剩下条件行动 KL。若两者都改变，不能省略其中任何一组项。

Rényi 不能把条件散度直接按 P 平均。一个充分组合条件是，对每个相关历史都有确定的统一界

$$D_\alpha(P_t(\cdot \mid h_{<t}) \parallel Q_t(\cdot \mid h_{<t})) \leq \varepsilon_t.$$

为简化记号从 $t = 1$ 开始且初始历史固定。在 Q 下从最后一步取条件期望，

$$\mathbb{E}_Q[L_t^\alpha \mid h_{<t}] \leq e^{(\alpha-1)\varepsilon_t}.$$

此前各步密度比的乘积已经由当前历史确定，因此取这一步的条件期望时，可以把它提出；每消去一步至多乘上这个常数。反复迭代后

$$\mathbb{E}_Q L_{1:T}^\alpha \leq e^{(\alpha-1)\sum_t \varepsilon_t}, \quad D_\alpha(P_{1:T} \| Q_{1:T}) \leq \sum_t \varepsilon_t.$$

若只在某种历史分布下给出平均条件界，后续选择可能偏向高散度历史，不能据此使用这个组合结论。

固定观测步数时，直接使用上面的有限求和即可。若共同停止规则给出 $\tau \leq T$ ，停止后补同一个吸收符号，其条件信息代价为零，公式仍适用。无界停时则应确认在所比较的规律下几乎处处终止；一种足够的取极限条件是截断累计对数似然比 $\log L_{0:\tau \wedge n}$ 在 P 下均匀可积并收敛到停止轨迹的对数密度比。此时左侧期望可取极限，右侧的非负条件 KL 用单调收敛。终止本身不能代替这些可积条件。隐私分析若使用组合式，还必须另外规定相邻输入、随机机制，以及对全部相邻输入统一成立的界；单个分布对的散度不是完整隐私定义。

自适应观测的区分下界 设算法 $\mathcal{A}$ 在时刻 t 根据历史选择来源或状态行动对 (s, a) ，观测核在环境 j 中为 $P_j(\cdot | s, a)$ 。若初始规律相同、条件行动规则相同，且观测在给定历史及当前 (s, a) 后使用该核，轨迹链式法则可按访问位置分组：

$$D_{\text{KL}}(\mathbb{P}_0^{\mathcal{A}} \| \mathbb{P}_1^{\mathcal{A}}) = \sum_{s,a} \mathbb{E}_0 N_T(s, a) D_{\text{KL}}(P_0(\cdot | s, a) \| P_1(\cdot | s, a)).$$

这里 $N_T(s, a)$ 为 T 步中的访问次数；等式来自 $\sum_t \mathbb{I}\{(S_t, A_t) = (s, a)\} = N_T(s, a)$ 。它是由算法和环境共同产生的随机量，不能预先替换成均匀独立的样本数。核若还依赖其他历史，保留逐步条件 KL 形式，不能强行按固定位置常数提取。

考虑两个可选 Bernoulli 来源 A, B 。环境 0 的均值为 $(1/2 + \varepsilon, 1/2)$ ，环境 1 为 $(1/2 + \varepsilon, 1/2 + 2\varepsilon)$ ， $0 < \varepsilon < 1/4$ 。每次访问给出独立于过去的相应来源新观测，但来源选择允许自适应。两个环境的最优来源相反，全部区分信息只来自 B ，单次 KL 为

$$\kappa(\varepsilon) = D_{\text{KL}}(\text{Bernoulli}(1/2) \| \text{Bernoulli}(1/2 + 2\varepsilon)) = -\frac{1}{2} \log(1 - 16\varepsilon^2).$$

故轨迹 KL 为 $\mathbb{E}_0 N_T(B) \kappa(\varepsilon)$ 。若输出的来源在两个环境下的错误都不超过 $\delta < 1/2$ ，检验恒等式迫使 TV 至少为 $1 - 2\delta$ ，Pinsker 进一步给出

$$\mathbb{E}_0 N_T(B) \geq \frac{2(1 - 2\delta)^2}{\kappa(\varepsilon)}.$$

例如 $\varepsilon = 0.1, \delta = 0.1$, 有 $\kappa \approx 0.08718$, 期望访问至少约 14.68 次。当 ε 小时, $\kappa = 8\varepsilon^2 + O(\varepsilon^4)$, 因此固定错误水平需要 ε^{-2} 量级的区分观测。这是任何满足错误要求的算法都需要达到的观测次数下界; 要证明某个算法能够用这么多观测完成任务, 还需要另外给出算法和上界。推广到无界停止必须满足上一段的终止和可积条件; 更具体的价值或累计决策损失还要引入相应任务定义。

11.3 随机分布扰动与任务稳定性

同一个预测器在两个测试总体上运行, 平均损失能相差多少? 这个问题固定评价规则, 只改变数据分布。如果预测器又是从当前评价样本中挑选的, 问题就多了一层: 较低的样本损失可能来自选择过程, 而非真实风险降低。下面先控制固定函数的期望变化, 再把样本与算法输出的依赖纳入比较。

11.3.1 固定评价下的期望稳定性

取值范围、输入敏感程度和尾部条件, 分别提供三种可以利用的信息。一个函数可能同时有界、满足 Lipschitz 条件并具有次高斯尾部。因此同一任务可以使用多个界, 再比较哪个界给出的控制更紧。

11.3.1.1 有界函数下的期望变化

设固定可测损失 f 取值于 $[0, 1]$ 。逐点恒等式 $f(x) = \int_0^1 \mathbb{I}\{f(x) > t\} dt$ 与 Tonelli 定理给出

$$|\mathbb{E}_P f - \mathbb{E}_Q f| \leq \int_0^1 |P(f > t) - Q(f > t)| dt \leq d_{TV}(P, Q).$$

这也说明事件概率控制为何足以控制所有这一范围内的损失。若 $a \leq f \leq b$, 对 $(f - a)/(b - a)$ 使用同一式子, 得到

$$|\mathbb{E}_P f - \mathbb{E}_Q f| \leq (b - a)d_{TV}(P, Q).$$

特别地, $|f| \leq 1$ 时常数是 2, 不能把它与 $0 \leq f \leq 1$ 混用。取两点上的 $P = \delta_0, Q = \delta_1$ 和 $f(0) = -1, f(1) = 1$, 期望差为 2, 已经表明这个因子不能删除。结合 Pinsker, 还可用 $(b - a)\sqrt{D_{KL}(P||Q)}/2$ 控制期望差; 若 KL 无限, 这个途径不给出有限信息, 但 TV 界仍有效。

对罕见失败事件, 除了 TV 的加性误差, 还可以利用似然比高阶矩。设 $P \ll Q, L = dP/dQ$, 并且某个 $\alpha > 1$ 满足 $D_\alpha(P||Q) < \infty$ 。由 Hölder 不等式,

$$P(A) = \mathbb{E}_Q[L \mathbb{I}_A] \leq (\mathbb{E}_Q L^\alpha)^{1/\alpha} (\mathbb{E}_Q \mathbb{I}_A^{\alpha/(\alpha-1)})^{(\alpha-1)/\alpha}.$$

代入 Rényi 散度定义, 得到

$$P(A) \leq \exp\left\{\frac{\alpha-1}{\alpha} D_\alpha(P\|Q)\right\} Q(A)^{(\alpha-1)/\alpha}. \quad (11.30)$$

若 $Q(A) = 0$, 绝对连续直接给出 $P(A) = 0$, 无需计算无穷与零的乘积。若 $Q(A) = 0 < P(A)$, 所需方向的绝对连续已经失败, 相应散度无限。例如 $D_2(P\|Q) \leq \log 4$ 、 $Q(A) \leq 10^{-4}$ 时, 上界为 $2\sqrt{10^{-4}} = 0.02$ 。这是从参考规律 Q 到目标规律 P 的单向风险迁移, 不保证反向同样成立。

有界性不能只在常见样本上成立。取 $Q = \delta_0$ 、 $P_\varepsilon = (1-\varepsilon)\delta_0 + \varepsilon\delta_{1/\varepsilon}$, 对无界函数 $f(x) = x$, TV 为 ε , 期望差却恒为 1。少量尾部质量足以破坏只依赖 TV 的小误差结论, 必须另外控制函数增长或分布尾部。

11.3.1.2 敏感性约束下的期望变化

若损失不会因输入小幅移动而剧变, 就应让这种敏感性进入界。设 $P, Q \in \mathcal{P}_1(\mathcal{X})$, 且 $|f(x) - f(y)| \leq Ld(x, y)$ 。由于 $|f(x)| \leq |f(x_0)| + Ld(x, x_0)$, 两边期望均有限。任意耦合 $\gamma \in \Pi(P, Q)$ 满足

$$|\mathbb{E}_P f - \mathbb{E}_Q f| = \left| \int (f(x) - f(y)) d\gamma \right| \leq L \int d(x, y) d\gamma.$$

对耦合取下确界便得到

$$|\mathbb{E}_P f - \mathbb{E}_Q f| \leq L W_1(P, Q).$$

这也可由式 (11.24) 直接读出。界不要求函数有界, 但同时使用了一阶矩和相对于所选距离的 Lipschitz 条件。

对 $\delta_0, \delta_\varepsilon$, 其中 $\varepsilon > 0$, 均值函数 $f(x) = x$ 的变化恰为 $\varepsilon = W_1$, 事件函数 $g(x) = \mathbb{I}\{x > 0\}$ 的变化却为 1。后者在零附近不连续, 无法用一个有限的 Lipschitz 常数控制。图 11.4 把同一质量位移对应的这两种评价分开显示; 小搬运距离确实保护平滑评价, 但不能据此声称所有阈值事件都稳定。

MMD 提供另一种敏感性约束。若同一损失 f 属于核 k 的 RKHS $\mathcal{H}_k$, 且核均值存在, 则再生性质和 Cauchy-Schwarz 不等式给出

$$|\mathbb{E}_P f - \mathbb{E}_Q f| = |\langle f, \mu_P - \mu_Q \rangle_{\mathcal{H}_k}| \leq \|f\|_{\mathcal{H}_k} \text{MMD}_k(P, Q).$$

下标 k 显式标明这里沿用的核空间和 MMD。必须知道 f 属于该空间及其范数; 核具有特征性只保证分离分布, 不自动给出任意任务函数的有限范数。同样, 若底层成本只比较图像亮度, 而任务依赖没有计入成本的位置变化, 不能声称损失相对于该成本是 Lipschitz。成本与核是任务假设的一部分。




图 11.4 同一小位移对两种固定评价的影响。取 $P = \delta_0$ 、 $Q = \delta_\varepsilon$ 、 $\varepsilon > 0$ ，底层距离为绝对值。左图的 1-Lipschitz 函数 $f(x) = x$ 变化 ε ；右图的事件函数 $\mathbb{1}\{x > 0\}$ 变化 1。横向位置仅作示意，结论对任意正的 ε 成立。

11.3.1.3 指数矩条件下的期望变化

有些损失没有统一上界，也难以给出输入空间的敏感常数，但在参考分布下可控制其尾部。第 10.3.3 节允许用密度比换测度；下面用 KL 和指数矩代替密度比的逐点控制。证明的关键是指数倾斜：按 e^f 重新加权参考分布，使较大函数值获得更多质量。

定理 11.23 Donsker-Varadhan 变分表达 设 $P \ll Q$ 。对每个有界可测实函数 f ,

$$D_{\text{KL}}(P||Q) \geq \mathbb{E}_P f - \log \mathbb{E}_Q e^f. \quad (11.31)$$

而且在扩展实数意义下,

$$D_{\text{KL}}(P||Q) = \sup_{f \text{ 有界可测}} \{\mathbb{E}_P f - \log \mathbb{E}_Q e^f\}. \quad (11.32)$$

证明. 给定有界 f ，令 $Z_f = \mathbb{E}_Q e^f$ ，并定义

$$\frac{dQ_f}{dQ} = \frac{e^f}{Z_f}.$$

因 $0 < Z_f < \infty$ ，且密度比严格正， Q_f 与 Q 等价。若 $D_{\text{KL}}(P||Q) < \infty$ ，对数密度比可积，乘法法则给出完整的倾斜恒等式

$$\begin{aligned} D_{\text{KL}}(P||Q_f) &= \mathbb{E}_P \left[\log \frac{dP}{dQ} - f + \log Z_f \right] \\ &= D_{\text{KL}}(P||Q) - \mathbb{E}_P f + \log Z_f. \end{aligned}$$

左侧非负即得下界；若原 KL 无限，右侧有限，下界仍成立。

为证明上确界恰好等于 KL, 不能直接假设 $\log(dP/dQ)$ 有界。记 $L = dP/dQ$, 在 $L = 0$ 处令 $\log L = -\infty$, 取

$$f_n = \max\{-n, \min\{\log L, n\}\}.$$

由于 $P(L = 0) = 0$, 且 $\mathbb{E}_P(\log L)^- = \int_{\{L < 1\}} -L \log L dQ < \infty$, 负部由支配收敛、正部由单调收敛可知 $\mathbb{E}_P f_n \rightarrow D_{\text{KL}}(P||Q)$, 允许极限无限。另一方面, $e^{f_n} \rightarrow L$, 且 $e^{f_n} \leq 1 + L$ 。在 Q 下支配收敛给出 $\mathbb{E}_Q e^{f_n} \rightarrow 1$, 故对应变分值趋向 KL。结合已证上界, 得到等式。若 $\log L$ 本身有界, 它直接取到等号; 一般只保证截断序列逼近。 ■

取两点均匀参考分布 $Q = (1/2, 1/2)$, $f = (0, \log 3)$, 则 $Z_f = 2$ 、 $Q_f = (1/4, 3/4)$ 。此时 $\mathbb{E}_{Q_f} f = (3/4) \log 3$, $D_{\text{KL}}(Q_f||Q) = (3/4) \log 3 - \log 2$, 两者之差正是 $\log Z_f$ 。这次倾斜只改变概率权重, 没有改变样本的取值。

现在令 g 允许无界。假设 $P \ll Q$ 、 $g \in L^1(P)$, 并且对所选 $\lambda > 0$ 有 $\mathbb{E}_Q e^{\lambda g} < \infty$ 。取 $g_n = \max\{-n, \min\{g, n\}\}$, 将定理用于 λg_n 。因 $|g_n| \leq |g|$ 、 $e^{\lambda g_n} \leq 1 + e^{\lambda g}$, 分别在 P, Q 下支配收敛, 得到

$$\mathbb{E}_P g \leq \frac{D_{\text{KL}}(P||Q) + \log \mathbb{E}_Q e^{\lambda g}}{\lambda}. \quad (11.33)$$

KL 有限才能让这个界提供有限的控制。若还知道 $g \in L^1(Q)$, 且在 Q 下对所有 $t \in \mathbb{R}$ 满足

$$\log \mathbb{E}_Q e^{t(g - \mathbb{E}_Q g)} \leq t^2 \sigma^2 / 2,$$

则分别对 $g - \mathbb{E}_Q g$ 和其相反数应用上式, 得到

$$|\mathbb{E}_P g - \mathbb{E}_Q g| \leq \frac{D_{\text{KL}}(P||Q)}{\lambda} + \frac{\lambda \sigma^2}{2}.$$

当 KL 与 σ^2 都严格正且有限时, 取 $\lambda = \sqrt{2D_{\text{KL}}(P||Q)/\sigma^2}$, 得到

$$|\mathbb{E}_P g - \mathbb{E}_Q g| \leq \sqrt{2\sigma^2 D_{\text{KL}}(P||Q)}. \quad (11.34)$$

KL 为零时 $P = Q$; $\sigma^2 = 0$ 时 g 在 Q 下为常量, 由绝对连续在 P 下也如此, 所以这两个边界情形仍成立。对 $Q = \mathcal{N}(0, 1)$ 、 $P = \mathcal{N}(m, 1)$ 、 $g(x) = x$, 方差代理为 1, KL 为 $m^2/2$, 上界恰等于真实期望差 $|m|$ 。整个推导只控制两张既定分布下的期望; 数据依赖的选择需要下一小节另行处理。

11.3.2 数据依赖评价下的风险控制

设 $S = (Z_1, \dots, Z_n)$ 为独立同分布样本, 随机算法根据 S 输出 W 。固定参数 w 时, 经验损失是独立样本的平均; 把它换成 W 以后, 参数和样本相互

依赖，原先对固定参数的集中结论不能直接代入。可以比较真实联合分布与人为解除依赖后的分布，也可以先建立覆盖全部候选的同一事件。

11.3.2.1 平均评价偏差的信息控制

设可测损失 $\ell(w, Z) \in [0, 1]$ ，新样本 Z 服从与训练样本相同的总体规律，定义

$$R(w) = \mathbb{E}_Z \ell(w, Z), \quad \hat{R}_S(w) = \frac{1}{n} \sum_{i=1}^n \ell(w, Z_i),$$

$$g(S, w) = R(w) - \hat{R}_S(w).$$

固定 w 时， $\mathbb{E}_S g(S, w) = 0$ 。Hoeffding 引理对每个中心化损失给出指数矩，再用独立性相乘，有

$$\mathbb{E}_S e^{tg(S, w)} \leq e^{t^2/(8n)}, \quad t \in \mathbb{R}.$$

界对所有 w 使用同一个常数。在 $Q = P_S \otimes P_W$ 下，样本与算法输出被设为独立，再对 w 积分，因此 $\mathbb{E}_Q g = 0$ ，且 g 的方差代理为 $1/(4n)$ 。真实评价使用联合分布 $P = P_{S, W}$ ，换测度的代价正是

$$D_{\text{KL}}(P \| Q) = I(S; W).$$

若互信息有限，式 (11.34) 给出

$$|\mathbb{E}_{S, W} \{R(W) - \hat{R}_S(W)\}| \leq \sqrt{\frac{I(S; W)}{2n}}. \quad (11.35)$$

无限互信息时右侧无限，不提供有效保证。左侧先对泛化差求平均，再取绝对值；正负差值会相互抵消。因此它不控制 $\mathbb{E}|R(W) - \hat{R}_S(W)|$ ，也不直接保证每次训练的差值都很小。

例如算法只能输出 M 种预测器，则 $I(S; W) \leq H(W) \leq \log M$ ，平均偏差至多 $\sqrt{\log M/(2n)}$ 。若算法完全忽略训练样本，互信息为零，平均有符号差也为零，但每个样本的经验风险仍会波动。反过来，连续确定性输出可能携带无限互信息；参数维数有限本身不能保证信息有限。这里所控制的是输出对评价样本的依赖，不能直接替换成参数个数。

11.3.2.2 候选分布风险的同时控制

若希望在看到样本后选择一张参数分布 Q_S ，再从中抽取参数用于预测，要评价的就是各参数风险按 Q_S 加权后的平均。为了允许数据参与这项选择，可以先对所有候选分布建立共同的高概率事件。PAC-Bayes 界采用见数据前固定的先验 P_0 作为参考，惩罚候选分布偏离它的 KL。这里的“先验”和“候选分布”是风险分析对象，不要求来自贝叶斯生成模型。

定理 11.24 固定分析参数下的基础 PAC-Bayes 界 在上述独立同分布样本和 $[0, 1]$ 损失设定下, 令 P_0 在观察 S 前固定, 且与 S 独立。对任意预先固定的 $\lambda > 0$ 与 $0 < \delta < 1$, 以至少 $1 - \delta$ 的概率, 同时对所有 $Q \ll P_0$ 有

$$\mathbb{E}_Q R(\theta) \leq \mathbb{E}_Q \hat{R}_S(\theta) + \frac{D_{\text{KL}}(Q \| P_0) + \log(1/\delta)}{\lambda} + \frac{\lambda}{8n}. \quad (11.36)$$

KL 无限时将右侧解释为无限。

证明. 对每个固定 θ , Hoeffding 引理给出 $\mathbb{E}_S e^{\lambda(R(\theta) - \hat{R}_S(\theta))} \leq e^{\lambda^2/(8n)}$ 。先验独立于样本, Tonelli 定理允许对同一个 P_0 平均:

$$\mathbb{E}_S \mathbb{E}_{\theta \sim P_0} e^{\lambda(R(\theta) - \hat{R}_S(\theta))} \leq e^{\lambda^2/(8n)}.$$

由 Markov 不等式, 事件

$$\mathcal{E} = \left\{ S : \mathbb{E}_{P_0} e^{\lambda(R - \hat{R}_S)} \leq \frac{e^{\lambda^2/(8n)}}{\delta} \right\}$$

满足 $P_S(\mathcal{E}) \geq 1 - \delta$ 。对任意固定在这个事件内的样本, 实现后的函数 $f(\theta) = \lambda(R(\theta) - \hat{R}_S(\theta))$ 有界。对所有 $Q \ll P_0$ 分别使用式 (11.31), 得到

$$\lambda \mathbb{E}_Q (R - \hat{R}_S) \leq D_{\text{KL}}(Q \| P_0) + \log \mathbb{E}_{P_0} e^{\lambda(R - \hat{R}_S)} \leq D_{\text{KL}}(Q \| P_0) + \frac{\lambda^2}{8n} + \log(1/\delta).$$

除以 λ 即得所需结论。事件只包含先验积分, 不随 Q 改变, 因此在事件发生后选择的数据依赖 Q_S 也被同时覆盖。 ■

若 P_0 均匀分布在预先指定的 M 个候选上, 选择其中一个候选的点质量 Q 具有 KL 为 $\log M$, 便得到这 M 个预测器的统一风险控制。若 P_0 为连续分布, 单点候选通常不对它绝对连续, 不能仍把该点估计作为有限 KL 的候选代入。

“固定 λ ”是事件成立的条件。观察数据后逐个候选优化右侧的 λ , 或根据同一评价样本重选先验, 都超出了上述事件。可以预设可数参数网格并分配失败概率后使用并集界, 也可以用独立样本确定先验, 再对剩余评价样本条件化应用定理。这些额外步骤不能省略。互信息界比较联合规律与边缘乘积, 给出平均偏差; 此处比较候选分布与先验, 给出同时风险界, 两者复用换测度代数但不是同一个保证。

11.4 随机分布空间上的优化

前面假定分布已经给定, 计算它们的差异。现在反过来问: 根据收益、均值等要求, 应当选什么分布? 如果目标分布已经确定, 但直接计算太困难,

又该怎样逼近它？还有一种任务保持两边分布不变，只优化来源与目标的联合配对。这些任务都能限制到参数族中求解，但参数步长是否意味着小的分布变化，还需要局部几何来判断。

11.4.1 目标分布的选择与逼近

下面先在收益与偏离参考分布之间作权衡，再在满足给定矩的分布中选择最大熵者，最后逼近一个已确定的后验分布。三种任务可能得到相似的指数形式或 KL 目标，但已知量和可行集合不同，各自的支持、归一化与最优性条件也需要分别检查。

11.4.1.1 参考分布下的收益与偏离权衡

设 P_0 是可以采样的参考规律， f 为有界可测收益。只追求最大收益可能把质量全部集中到极少数点；同时扣除偏离参考规律的 KL，就得到下面的分布优化。

定理 11.25 Gibbs 变分式 对有界可测 f ,

$$\log \mathbb{E}_{P_0} e^f = \sup_{Q \ll P_0} \{\mathbb{E}_Q f - D_{\text{KL}}(Q \| P_0)\}. \quad (11.37)$$

KL 无限时目标约定为 $-\infty$ ，唯一最优分布为

$$\frac{dQ^*}{dP_0} = \frac{e^f}{Z_f}, \quad Z_f = \mathbb{E}_{P_0} e^f.$$

证明. 有界性保证 $0 < Z_f < \infty$ ，且 Q^* 与 P_0 等价。对任何有限 KL 的 $Q \ll P_0$,

$$\log \frac{dQ}{dQ^*} = \log \frac{dQ}{dP_0} - f + \log Z_f.$$

各项在 Q 下可积，故倾斜恒等式给出

$$\mathbb{E}_Q f - D_{\text{KL}}(Q \| P_0) = \log Z_f - D_{\text{KL}}(Q \| Q^*) \leq \log Z_f.$$

无限 KL 候选的目标已为 $-\infty$ 。对 Q^* ， $\log(dQ^*/dP_0) = f - \log Z_f$ 有界，所以自身收益与 KL 都有限，可以直接代入取到等号。Gibbs 不等式的等号条件说明最优分布唯一。 ■

这里优化的是分布，Donsker-Varadhan 表达优化的则是测试函数；两条变分式共用同一倾斜恒等式，却交换了固定对象和优化对象。允许无界 f 时，至少需要 $0 < Z_f < \infty$ 才能定义 Q^* ；若还满足 $\mathbb{E}_{P_0}[e^f |f|] < \infty$ ，则 $f \in L^1(Q^*)$ ，最优表达中的两项都有限。对其他候选，也须限制到 $f \in L^1(Q)$ 且 KL 有限的定义域。

只有归一化常数有限并不够。例如在整数 $k \geq 1$ 上取 $P_0(k) = Ce^{-k}/k^2$ 、 $f(k) = k$ ，其中 C 归一化 P_0 。则 $Z_f = C \sum_{k \geq 1} k^{-2} < \infty$ ，而 $Q^*(k)$ 正比于 k^{-2} ，导致 $\mathbb{E}_{Q^*} f = \infty$ 且 KL 无限。此时不能把 Q^* 代入 $\infty - \infty$ 。若 f 为有限实值且 $Z_f < \infty$ ，令 $Z_n = \mathbb{E}_{P_0}[e^f \mathbb{I}_{\{|f| \leq n\}}]$ ，在 $Z_n > 0$ 时取

$$\frac{dQ_n}{dP_0} = \frac{e^f \mathbb{I}_{\{|f| \leq n\}}}{Z_n}.$$

其收益和 KL 有限，目标恰为 $\log Z_n \rightarrow \log Z_f$ 。因而在有限目标定义域上仍可逼近上确界，不必有可直接代入的最优分布。

对有界收益 r 加入温度 $\beta > 0$ ，令 $f = r/\beta$ ，可得

$$\sup_{Q \ll P_0} \{\mathbb{E}_{Q^*} r - \beta D_{\text{KL}}(Q \| P_0)\} = \beta \log \mathbb{E}_{P_0} e^{r/\beta}, \quad Q^* \propto P_0 e^{r/\beta}.$$

较小温度更偏向高收益区域，也可能使重要性权重集中、采样方差增大。KL 正则描述相对于 P_0 的概率偏离；若某种失败事件必须受控，仍需用上一节的风险迁移条件或另加约束，不能把正则项本身当成安全保证。

11.4.1.2 矩约束下的最大熵选择

若只知道均值或协方差，没有指定收益函数，哪些分布与这些信息相容？最大熵原理在满足这些要求的分布中选择熵最大的一个，即在已有信息允许的范围保留尽可能多的不确定性。这个优化准则不表示所选分布已被观测证明为真；参考测度和矩约束仍是建模选择。

固定参考测度 μ ，要求密度 p 满足

$$\int p \, d\mu = 1, \quad \int T(x)p(x) \, d\mu(x) = \tau.$$

若存在有限参数 λ ，使

$$p_\lambda(x) = \exp\{\lambda^\top T(x) - A(\lambda)\}, \quad A(\lambda) = \log \int e^{\lambda^\top T(x)} \, d\mu(x) < \infty$$

归一化并满足这些矩约束，则它是最大熵的候选。形式上，对熵加归一化和矩约束的 Lagrange 项，密度方向的一阶条件为 $-\log p - 1 + \lambda^\top T + a = 0$ ，从而给出上述指数形式。但这一步没有证明解存在，也没有处理所有无限维变分的合法性；真正的最优性可由 KL 直接核验。

对任意同样可行、统计量可积且熵有限的密度 p ，若候选自身也满足这些有限性条件，

$$\begin{aligned} D_{\text{KL}}(p \| p_\lambda) &= \int p \log p \, d\mu - \lambda^\top \tau + A(\lambda) \\ &= -h_\mu(p) + h_\mu(p_\lambda) \geq 0. \end{aligned}$$

因此候选最大化熵，等号当且仅当两密度几乎处处相同。矩约束不可达、配分函数无限或最大熵没有上界时，乘子方程不能弥补这些缺口。即使最大熵分布存在，边界约束也可能只能由无穷自然参数的极限表示。

固定均值 $\mathbf{m}$ 和正定协方差 Σ 时， $q = \mathcal{N}(\mathbf{m}, \Sigma)$ 给出一个完整实例。其对数密度为

$$\log q(\mathbf{x}) = -\frac{d}{2} \log(2\pi) - \frac{1}{2} \log \det \Sigma - \frac{1}{2} (\mathbf{x} - \mathbf{m})^\top \Sigma^{-1} (\mathbf{x} - \mathbf{m}).$$

任意具有同样均值和协方差的密度 p 都满足

$$\mathbb{E}_p[(\mathbf{X} - \mathbf{m})^\top \Sigma^{-1} (\mathbf{X} - \mathbf{m})] = \text{tr}(\Sigma^{-1} \Sigma) = d.$$

因而 $\mathbb{E}_p \log q = \mathbb{E}_q \log q$ ，在 $h(p)$ 有限时，

$$D_{\text{KL}}(p \| q) = h(q) - h(p) \geq 0, \quad h(p) \leq \frac{1}{2} \log \{(2\pi e)^d \det \Sigma\}.$$

等号唯一对应高斯。这仍是在固定坐标和 Lebesgue 参考测度下比较微分熵。协方差奇异时，分布被限制在低维仿射子空间，不能继续使用原空间中的密度公式；须改用子空间参考测度。

指数形式还把分布优化与参数表示联系起来。对前章的指数族

$$p_\eta(x) = h(x) \exp\{\eta^\top T(x) - A(\eta)\},$$

在允许交换微分积分的自然参数内部， $\nabla A(\eta) = \mathbb{E}_\eta T = \tau$ ， $\nabla^2 A(\eta) = \text{Cov}_\eta(T)$ 。自然参数 η 指定指数权重，均值参数 τ 指定统计量平均。回用第4章的凸共轭，定义

$$A^*(\tau) = \sup_{\eta} \{\eta^\top \tau - A(\eta)\}. \quad (11.38)$$

若 $\tau = \nabla A(\eta)$ 由有限自然参数实现，凸性的一阶不等式给出 $A(\zeta) \geq A(\eta) + \tau^\top (\zeta - \eta)$ 。移项可知共轭上确界在 η 达到，且

$$A^*(\tau) = \eta^\top \tau - A(\eta) = \int p_\eta \log \frac{p_\eta}{h} d\mu.$$

最后一个量是相对于基准项 h 的负熵；若 h 本身为概率密度，它就是 KL。只有 $h = 1$ 时才能直接写成普通负熵。

两组参数能否在局部互换，还取决于统计量有无冗余。所谓最小表示，是指不存在非零向量 $\mathbf{a}$ ，使 $\mathbf{a}^\top T(x)$ 在基准测度 $h d\mu$ 下几乎处处为常量。在自然参数空间的开内部，这个条件给出

$$\mathbf{a}^\top \text{Cov}_\eta(T) \mathbf{a} = \text{Var}_\eta(\mathbf{a}^\top T) > 0 \quad (\mathbf{a} \neq \mathbf{0}),$$

因为有限自然参数的指数因子严格为正，模型分布与基准测度具有相同的零测集。所以协方差正定， $d\tau = \nabla^2 A d\eta$ 的 Jacobian 可逆，由逆函数定理可得两组参数局部一一对应。若统计量有含常量项的仿射冗余，例如某一坐标恒为 1，协方差就会奇异；只排除不同统计量之间的线性组合还不够。

上面的指数形式要求均值能由有限自然参数实现。有限配置中，某些边界均值只允许概率集中在少数点上，无法用有限参数表示。下面直接在全部可行概率表上优化，从而把这些边界情形也包括进来。

定理 11.26 有限配置上的配分函数与最大熵对偶 设 D 为有限非空配置集， $T : D \rightarrow \mathbb{R}^m$ ，基准权重恒为 1。定义

$$A(\theta) = \log \sum_{z \in D} e^{\langle \theta, T(z) \rangle}, \quad \mathcal{M} = \text{conv}\{T(z) : z \in D\}.$$

对 $\mu \in \mathcal{M}$ ，令

$$H^*(\mu) = \max_{q: \mathbb{E}_q T = \mu} H(q),$$

其中 q 遍历 D 上的全部概率质量函数。则在整个 $\mathcal{M}$ 上有 $A^*(\mu) = -H^*(\mu)$ ，在外部有 $A^* = +\infty$ ，且

$$A(\theta) = \max_{\mu \in \mathcal{M}} \{\langle \theta, \mu \rangle + H^*(\mu)\}. \quad (11.39)$$

证明. 有限概率单纯形紧；给定可行均值后的约束闭且非空，熵在单纯形上连续，因此每个 $H^*(\mu)$ 都能达到。令 $p_\theta(z) = e^{\langle \theta, T(z) \rangle - A(\theta)}$ 。对任意质量函数 q ，展开有限 KL 得到

$$\langle \theta, \mathbb{E}_q T \rangle + H(q) = A(\theta) - D_{\text{KL}}(q \| p_\theta) \leq A(\theta),$$

且在 $q = p_\theta$ 处取等号。把所有 q 按均值分组，组内线性项相同，只需保留最大熵者，即得式 (11.39)。

为证明边界处也有共轭等式，在 $\mathcal{M}$ 上令 $f = -H^*$ ，在外部令 $f = +\infty$ 。取两个均值及其最大熵分布 q_1, q_2 ，混合 $tq_1 + (1-t)q_2$ 的均值为对应均值的凸组合。熵凹性给出

$$H^*(t\mu_1 + (1-t)\mu_2) \geq H(tq_1 + (1-t)q_2) \geq tH^*(\mu_1) + (1-t)H^*(\mu_2).$$

所以 f 凸。若 $\mu_n \rightarrow \mu$ 且各均值可行，先取使最大熵值趋于上极限的子列，再从对应的最大熵分布中取收敛子列 $q_{n_k} \rightarrow q$ 。有限维均值映射连续，故 $\mathbb{E}_q T = \mu$ ；熵连续性给出

$$\limsup_n H^*(\mu_n) = H(q) \leq H^*(\mu).$$

于是 H^* 上半连续。又因 $\mathcal{M}$ 闭, 扩展后的 f 在整个 $\mathbb{R}^m$ 上下半连续。由 $0 \leq H^* \leq \log |D|$ 和 $\mathcal{M} \neq \emptyset$, f 适当。前半证明已说明 $f^* = A$, 定理 4.24 于是给出 $A^* = f^{**} = f$, 包括边界均值和可行域外部。此证明不要求共轭上确界由有限自然参数达到。 ■

$\mathcal{M}$ 是实现统计量均值的凸包。统计量由各局部配置的指示函数组成时, 它称为边缘多面体; 属于该集合表示局部概率表能同时来自同一全局分布, 强于每张表单独归一化。例如两个二元变量的两张边缘表均令取值 1 的概率为 0.1, 则联合表不可能同时要求 $P(X=1, Y=1) = 0.9$ 。局部数字各自在 $[0, 1]$ 内, 并不足以保证共同可实现。

在 $\{0, 1, 2\}$ 上要求 $\mathbb{E}X = 1/2$ 时, 最大熵分布为 $p_j = t^j / (1 + t + t^2)$ 。均值方程给出

$$\frac{t + 2t^2}{1 + t + t^2} = \frac{1}{2}, \quad 3t^2 + t - 1 = 0, \quad t = \frac{\sqrt{13} - 1}{6} \approx 0.4343.$$

故 $(p_0, p_1, p_2) \approx (0.6162, 0.2676, 0.1162)$ 。自然参数是 $\lambda = \log t$, $H(p) = \log(1 + t + t^2) - \lambda/2$, 与共轭负熵一致。若均值改为边界值 0, 唯一可行分布为 δ_0 , 熵为零; 它由 $t \downarrow 0$ 、 $\lambda \rightarrow -\infty$ 逼近, 却没有有限自然参数表示。这正是分布最优解存在与有限参数实现之间的区别。

11.4.1.3 表示约束下的目标分布逼近

若目标已经由联合模型确定, 就不再自由选择规律, 而是在可计算的候选族中逼近它。固定观测 x 和模型参数 θ , 设

$$0 < p_\theta(x) = \int p_\theta(x, z) dz < \infty, \quad \pi(z) = p_\theta(z | x).$$

记候选密度为 q 。积分 $p_\theta(x)$ 给出观测 x 的概率密度, 常称为证据; 它可能难以计算。因此选用容易采样、也容易计算密度的候选 q 来逼近后验。

定义 11.27 证据下界 若 $q \ll \pi$ 且 $D_{\text{KL}}(q || \pi) < \infty$, 定义 证据下界 (evidence lower bound, ELBO) 为

$$\mathcal{L}(q, \theta; x) = \mathbb{E}_q \log \frac{p_\theta(x, Z)}{q(Z)}.$$

按对数比整体取期望, 不要求 $\mathbb{E}_q \log p_\theta(x, Z)$ 与 $\mathbb{E}_q \log q(Z)$ 各自有限。

有限 KL 保证上述整体对数比可积, 因为它等于 $\log p_\theta(x) - \log(q/\pi)$ 。直接分解就得到

$$\log p_\theta(x) = \mathcal{L}(q, \theta; x) + D_{\text{KL}}(q || p_\theta(\cdot | x)). \quad (11.40)$$

因此它确为下界，等号当且仅当 $q = \pi$ 。若 KL 无限，可以把 ELBO 扩展为 $-\infty$ ，但应使用 $\mathcal{L} = \log p_\theta(x) - D_{\text{KL}}$ 这一方向，不把右侧的 $-\infty + \infty$ 当作合法分解。

另一条常见推导在证据积分中乘除 q ，把积分改写成候选分布下的期望，再使用 Jensen 不等式。这个改写需要相反方向的覆盖条件 $\pi \ll q$ ，保证联合密度的正质量区域不会被 q 漏掉。若同时满足 $q \ll \pi$ 和上述可积性，则

$$\begin{aligned} \log p_\theta(x) &= \log \mathbb{E}_q \left[\frac{p_\theta(x, Z)}{q(Z)} \right] \\ &\geq \mathbb{E}_q \log \frac{p_\theta(x, Z)}{q(Z)} = \mathcal{L}(q, \theta; x). \end{aligned} \quad (11.41)$$

只满足 $q \ll \pi$ 时，KL 分解仍成立，但重要性期望实际为 $p_\theta(x)\pi(\{q > 0\})$ ，可能小于证据。例如 $\pi = (1/2, 1/2)$ 、 $q = (1, 0)$ ，KL 为 $\log 2$ ，ELBO 是 $\log p_\theta(x) - \log 2$ ，而重要性期望只恢复一半证据。反过来，若 $\pi = (1, 0)$ 、 $q = (1/2, 1/2)$ ，虽完整覆盖目标，但 q 在零后验区域放了质量，反向 KL 无限。两种支持要求不能互相代替。

固定模型后最大化 ELBO，等价于在候选族 $\mathcal{Q}$ 中最小化 $D_{\text{KL}}(q||\pi)$ 。当实际候选的 KL 有限时，可以把它拆成两项：候选族内再怎么改善也无法低于的值，以及当前候选高出该值的部分：

$$D_{\text{KL}}(q||\pi) = \inf_{\tilde{q} \in \mathcal{Q}} D_{\text{KL}}(\tilde{q}||\pi) + \left[D_{\text{KL}}(q||\pi) - \inf_{\tilde{q} \in \mathcal{Q}} D_{\text{KL}}(\tilde{q}||\pi) \right].$$

第一项是候选族本身无法消除的逼近误差，第二项是求解尚未达到族内最优而留下的额外误差。下确界不必由某个候选达到；已有有限 KL 的候选保证该下确界有限，所以这项分解也适用于最优候选不存在的情形。若同时拟合 θ ，证据和后验也随之改变，模型与真实数据规律的拟合误差是另一层问题，不等于这两项之和。

取 $Z \sim \mathcal{N}(0, 1)$ 、 $X | Z \sim \mathcal{N}(Z, 1)$ ，观测 $x = 1$ 。配平方得到后验 $\mathcal{N}(1/2, 1/2)$ ，证据为 $\mathcal{N}(0, 2)$ 。若 $q = \mathcal{N}(0, 1)$ ，

$$\begin{aligned} \log p(x) &= -\frac{1}{2} \log(4\pi) - \frac{1}{4} \approx -1.5155, \\ D_{\text{KL}}(q||\pi) &= \frac{1}{2} \left\{ 2 + \frac{1}{2} - 1 + \log(1/2) \right\} \approx 0.4034, \\ \mathcal{L}(q; x) &\approx -1.9189. \end{aligned}$$

三者满足精确分解。多变量情形把 q 限制为分块独立族，可能留下无法表示的后验相关性；求解更充分也不能消除这一表示限制。

分布蒸馏采用另一个给定目标：教师的条件分布 $P_T(\cdot | x)$ 。在固定输入权重下，最小化 $D_{\text{KL}}(P_T||Q_\phi)$ 等价于教师软标签下的交叉熵，要求学生覆

盖教师的正质量类别。反向 KL 改由学生平均，支持要求和最优近似都会改变。学生逼近教师，不自动意味着更接近真实标签规律。

对比学习采用另一种研究联合依赖的方式：给定 X ，把它按联合分布配对的 Y 放在若干独立抽取的 Y 中，让评分函数识别哪一个是真实配对。这样把联合依赖转化为分类任务。以一个具体的 InfoNCE 损失为例，取总候选数 $K \geq 2$ ，按目标联合分布抽取 (X, Y_1) ，再独立地按边缘 P_Y 抽取 $Y_2, \dots, Y_K$ ；这些负样本彼此独立，也独立于 (X, Y_1) 。对可测实值评分函数 s ，定义

$$\mathcal{L}_K = \mathbb{E} \left[-\log \frac{\exp s(X, Y_1)}{\sum_{j=1}^K \exp s(X, Y_j)} \right]. \quad (11.42)$$

它把相对评分归一化为候选类别概率，再惩罚未能认出正样本的预测。 K 包括一个正样本和 $K-1$ 个负样本；期望针对上述全部抽样。若该损失可积，则

$$\log K - \mathcal{L}_K \leq I(X; Y).$$

这个下界可从分类熵推得。等价地，先在 K 个位置中均匀选正样本位置 J ，令该位置与 X 按目标联合分布配对，其余位置仍为独立边缘样本。记整组观测为 $W = (X, Y_1, \dots, Y_K)$ 。同一个评分规则在各位置对称使用，所以平均分类损失仍为 $\mathcal{L}_K$ ；由对数损失的最优性，它不小于真实类别条件熵 $H(J | W)$ 。因此

$$\log K - \mathcal{L}_K \leq H(J) - H(J | W) = I(J; W).$$

还需说明识别正样本位置的信息不会超过目标互信息。令 P_j 为给定 $J = j$ 的 W 分布， $M = K^{-1} \sum_j P_j$ ，并以完全独立规律 $Q = P_X \otimes P_Y^{\otimes K}$ 作参照。若 $I(X; Y) < \infty$ ，每个 P_j 相对于 Q 只有正样本配对这一项密度比，所以

$$\begin{aligned} I(X; Y) &= \frac{1}{K} \sum_{j=1}^K D_{\text{KL}}(P_j \| Q) \\ &= \frac{1}{K} \sum_{j=1}^K D_{\text{KL}}(P_j \| M) + D_{\text{KL}}(M \| Q) \\ &= I(J; W) + D_{\text{KL}}(M \| Q) \geq I(J; W). \end{aligned}$$

中间等式将对数密度比拆成经过 M 的两项，再对 j 平均；互信息无限时原下界自动成立。又因分类损失非负， $\log K - \mathcal{L}_K \leq \log K$ ，有限候选数确实会限制这个下界的最大数值。不符合采样假设时，不能把优化该分类目标直接解释为增加原分布的互信息；即使下界合法，也不自动保证校准、语义质量或下游风险。

11.4.2 固定边缘的耦合优化

现在来源分布 P 和目标分布 Q 都已固定, 未知量是联合分布 $\gamma \in \Pi(P, Q)$ 。独立配对总可行, 却未必便宜; 在有限表格中, 优化要保持行和、列和不变, 决定每个来源点有多少质量送往每个目标点; 一般空间采用同样的边缘约束。定义 11.19 与式 (11.22) 已经给出可行集合和成本, 这里补足最小值的存在与有限求解。

11.4.2.1 最优耦合的存在条件

在无限空间中, 一系列概率分布的质量可能移到越来越远的位置, 使极限不再保留全部质量。最优搬运的存在性证明要排除这种情况, 同时确保极限仍有规定的边缘分布, 且成本不高于近最优方案的极限成本。第 10.4.3.2 节的概率测度弱收敛及紧性正好服务这三步。这里不重新定义它们: 变化对象是乘积空间上的概率测度, 测试函数是有界连续函数; 这不同于泛函分析中固定线性空间内由连续线性泛函检验的弱拓扑。二者都有“弱收敛”这一中文名称, 但不能不说明对象就互换结论。

定理 11.28 最优耦合存在 设 $\mathcal{X}, \mathcal{Y}$ 为 Polish 空间, P, Q 为其 Borel 概率测度。若成本 $c : \mathcal{X} \times \mathcal{Y} \rightarrow [0, \infty]$ 下半连续, 且至少有一个 $\gamma_0 \in \Pi(P, Q)$ 满足 $\int c d\gamma_0 < \infty$, 则存在有限成本耦合 γ^* 达到 $\mathcal{J}_c(P, Q) = \inf_{\gamma \in \Pi(P, Q)} \int c d\gamma$ 。

证明. 可行集合非空, 且成本非负、有有限可行值, 所以最优下确界有限。取近最优序列 $\gamma_n \in \Pi(P, Q)$, 使 $\int c d\gamma_n \rightarrow \mathcal{J}_c(P, Q)$ 。

Polish 空间上的 Borel 概率测度紧。任给 $\varepsilon > 0$, 分别选择紧集 K_x, K_y , 使 $P(K_x^c) < \varepsilon/2$ 、 $Q(K_y^c) < \varepsilon/2$ 。其乘积紧, 且任意可行耦合都满足

$$\gamma((K_x \times K_y)^c) \leq P(K_x^c) + Q(K_y^c) < \varepsilon.$$

因边缘固定, 这个紧集对全部 γ 同时适用, 从而 (γ_n) 一致紧。乘积空间仍为 Polish 空间, 定理 10.58 给出子列 $\gamma_{n_k} \Rightarrow \gamma^*$ 。

对任意有界连续 $a : \mathcal{X} \rightarrow \mathbb{R}$, 函数 $(x, y) \mapsto a(x)$ 有界连续, 故

$$\int a(x) d\gamma^*(x, y) = \lim_k \int a(x) d\gamma_{n_k}(x, y) = \int a dP.$$

有界连续函数区分 Borel 概率测度, 因此 γ^* 的第一边缘为 P 。同理第二边缘为 Q , 所以极限仍可行。

最后，对非负下半连续成本使用定理 10.56:

$$\int c \, d\gamma^* \leq \liminf_k \int c \, d\gamma_{n_k} = \mathcal{T}_c(P, Q).$$

可行性又给出反向不等式，所以等号成立且成本有限。 ■

最后一步的积分测度随 k 改变，不能用固定测度下的 Fatou 引理直接替代。非负性避免成本的负部失控，下半连续性保证极限不会突然增加成本；若修改这些假设，需要另给能实现同样作用的条件。存在联合耦合也不保证存在确定搬运映射。例如 $P = \delta_0$ 、 $Q = (\delta_{-1} + \delta_1)/2$ 时，唯一来源点必须把质量分成两半，任何单值映射都只能把它送到一个点。

11.4.2.2 有限空间的搬运求解

设来源点为 x_i 、目标点为 y_j ，概率向量为 $\mathbf{p}, \mathbf{q}$ ，各成本 $c_{i,j}$ 有限且非负。搬运表 γ 的行和是来源质量，列和是目标质量，问题为

$$\min_{\gamma_{i,j} \geq 0} \sum_{i,j} c_{i,j} \gamma_{i,j}, \quad \sum_j \gamma_{i,j} = p_i, \quad \sum_i \gamma_{i,j} = q_j.$$

独立表 $\gamma_{i,j} = p_i q_j$ 可行。约束集合闭，且每个元素在 $[0, 1]$ 内，因此它是紧多面体，线性目标可以取到最小值。

回用第 4 章线性规划，为两组边缘约束引入势函数 u_i, v_j ，保留 $\gamma_{i,j} \geq 0$ 作为取下确界的定义域：

$$\begin{aligned} \mathcal{L}(\gamma, \mathbf{u}, \mathbf{v}) &= \sum_{i,j} c_{i,j} \gamma_{i,j} + \sum_i u_i \left(p_i - \sum_j \gamma_{i,j} \right) + \sum_j v_j \left(q_j - \sum_i \gamma_{i,j} \right) \\ &= \sum_i u_i p_i + \sum_j v_j q_j + \sum_{i,j} (c_{i,j} - u_i - v_j) \gamma_{i,j}. \end{aligned} \quad (11.43)$$

如果某个系数 $c_{i,j} - u_i - v_j < 0$ ，将对应非负变量趋向无穷，Lagrangian 下确界就是 $-\infty$ 。若全部系数非负，下确界可在 $\gamma = \mathbf{0}$ 取到，值为 $\sum_i u_i p_i + \sum_j v_j q_j$ 。这里消元时边缘等式已进入 Lagrangian，不再限制 γ ，所以零表虽不是原问题的可行表，却可以用于计算对偶函数。于是

$$g(\mathbf{u}, \mathbf{v}) = \begin{cases} \sum_i u_i p_i + \sum_j v_j q_j, & u_i + v_j \leq c_{i,j} \text{ 对所有 } i, j, \\ -\infty, & \text{否则.} \end{cases}$$

最大化它得到

$$\max_{\mathbf{u}, \mathbf{v}} \left\{ \sum_i u_i p_i + \sum_j v_j q_j : u_i + v_j \leq c_{i,j} \right\}. \quad (11.44)$$

势函数约束来自消元后下确界有限的必要充分条件，不是额外猜出的搬运规则。对任意原始可行表，将 $u_i + v_j \leq c_{i,j}$ 逐项乘 $\gamma_{i,j}$ 并求和，立刻得到对偶值不超过搬运成本。有限维原问题可行且最优值有限，线性规划强对偶又保证两者最优值相等。

用一个只有两个位置的例子核对求解过程。来源与目标都位于 0, 2，令 $\mathbf{p} = (3/4, 1/4)$ 、 $\mathbf{q} = (1/4, 3/4)$ ， $c_{i,j} = |x_i - y_j|$ 。全部可行表都能写成

$$\gamma(a) = \begin{pmatrix} a & 3/4 - a \\ 1/4 - a & a \end{pmatrix}, \quad 0 \leq a \leq 1/4.$$

对角线成本为零，两个非对角线成本均为 2，故总成本为 $2 - 4a$ ，在 $a = 1/4$ 处最小：

$$\gamma^* = \begin{pmatrix} 1/4 & 1/2 \\ 0 & 1/4 \end{pmatrix}, \quad \sum_{i,j} c_{i,j} \gamma_{i,j}^* = 1.$$

对偶取 $\mathbf{u} = (0, -2)$ 、 $\mathbf{v} = (0, 2)$ ，四项和依次为 0, 2, -2, 0，均不超过对应成本 0, 2, 2, 0。对偶值为

$$\mathbf{u}^\top \mathbf{p} + \mathbf{v}^\top \mathbf{q} = -2(1/4) + 2(3/4) = 1.$$

弱对偶已足以核验最优性：所有可行表成本至少为 1，而上表恰好达到。图 11.5 比较这个表与独立配对，说明相同行列边缘不能决定搬运成本。

独立配对				最优配对			
	0	2	行和		0	2	行和
0	3/16	9/16	3/4	0	1/4	1/2	3/4
2	1/16	3/16	1/4	2	0	1/4	1/4
	1/4	3/4	列和		1/4	3/4	列和
搬运成本: 5/4				搬运成本: 1			

图 11.5 同一边缘约束下的两张搬运表。来源和目标都位于 0, 2，蓝色行和为 $\mathbf{p} = (3/4, 1/4)$ ，红色列和为 $\mathbf{q} = (1/4, 3/4)$ 。黄色单元格承担非零距离成本。独立表的成本为 5/4，最优表为 1；正文的势函数给出与最优表相等的对偶值。

11.4.3 参数化分布的迭代求解

选择目标分布、逼近后验和优化耦合，都可以在各自的可行分布中求解，也可以进一步限制到参数族 $\{p_\theta : \theta \in \Theta\}$ 中求解。后者减少表示和计算负担，却又引出一个问题：欧氏参数步长相同，是否意味着分布改变得同样多？高斯均值的同样位移在小噪声下更容易辨认，参数坐标的单位也可以任意缩放，因此需要根据分布自身定义局部步长。本节回用优化与流形中的切向量、度量工具，但度量由概率模型的局部 KL 建立。若参数化没有自动满足矩或边缘约束，仍要显式处理可行域，不能直接作无约束更新。

11.4.3.1 参数扰动的局部度量

改变参数值通常会改变分布；更换表示同一分布的坐标则不应该改变几何对象。先分析前一种真实扰动，再检查后一种坐标变化。得分和 Fisher 信息矩阵的正式定义沿用前章定义 10.106，这里增加把它们连接到局部 KL 所需的正则条件。

小参数变化下的分布差异 设参数域 $\Theta \subseteq \mathbb{R}^d$ ，共同参考测度为 μ 。固定内点 θ ，假设存在开邻域 U 和共同可测支持 S ，使所有 $\eta \in U$ 都在 S 上满足 $p_\eta > 0$ ，在外部为零。再假设 $p_\eta(x)$ 对参数二阶连续可微，其一、二阶导数分别由 μ -可积函数在 U 上一致控制。这些条件允许对归一化等式交换一、二阶微分和积分。沿用得分记号 $s_\theta(x) = \nabla_\theta \log p_\theta(x)$ ，有

$$\mathbb{E}_\theta s_\theta(X) = \int \nabla_\theta p_\theta(x) d\mu(x) = \mathbf{0}. \quad (11.45)$$

进一步要求

$$\mathbb{E}_\theta \|s_\theta(X)\|_2^2 < \infty, \quad \mathbb{E}_\theta \|\nabla_\theta^2 \log p_\theta(X)\|_{\text{op}} < \infty.$$

此时 Fisher 矩阵 $F(\theta) = \mathbb{E}_\theta [s_\theta s_\theta^\top]$ 有限。乘积法则给出

$$\nabla_\theta^2 p_\theta = p_\theta \{\nabla_\theta^2 \log p_\theta + s_\theta s_\theta^\top\}.$$

两边积分，左侧由二阶微分归一化等式为零，故

$$F(\theta) = -\mathbb{E}_\theta \nabla_\theta^2 \log p_\theta(X). \quad (11.46)$$

这就是此处使用的信息恒等式。不能只对得分的零均值求导而忽略积分权重 p_θ 也依赖参数。共同支持同样重要：例如均匀族 $\text{Unif}(0, \theta)$ 有移动边界，内部对数密度导数为 $-1/\theta$ ，其均值不为零；这不反驳恒等式，而是没有满足推导条件。

定理 11.29 KL 的局部二阶展开 在上述共同支持、交换微分及可积条件下, 进一步设 U 可取为凸集, 且对 P_θ -几乎处处的 x , $\nabla_\eta^2 \log p_\eta(x)$ 在 θ 处连续. 假设存在 $M \in L^1(P_\theta)$, 使

$$\sup_{\eta \in U} \|\nabla_\eta^2 \log p_\eta(x)\|_{\text{op}} \leq M(x)$$

几乎处处成立. 则当 $\delta \rightarrow \mathbf{0}$ 且 $\theta + \delta \in U$ 时,

$$D_{\text{KL}}(P_\theta \| P_{\theta+\delta}) = \frac{1}{2} \delta^\top \mathbf{F}(\theta) \delta + o(\|\delta\|_2^2). \quad (11.47)$$

证明. 对几乎处处的固定 x , 沿线段 $\theta + t\delta$ 作带积分余项的 Taylor 展开:

$$\begin{aligned} \log p_{\theta+\delta}(x) - \log p_\theta(x) &= \delta^\top \mathbf{s}_\theta(x) \\ &\quad + \int_0^1 (1-t) \delta^\top \nabla_\eta^2 \log p_\eta(x) \Big|_{\eta=\theta+t\delta} \delta \, dt. \end{aligned}$$

得分二阶可积保证一阶可积, 余项绝对值被 $\|\delta\|_2^2 M(x)/2$ 控制, 所以整个对数密度比在 P_θ 下可积. 按该分布取负期望, 一阶项由式 (11.45) 消失. 在乘积测度 $P_\theta \otimes dt$ 下, Hessian 的连续性和可积控制允许支配收敛, 故

$$\int_0^1 (1-t) \mathbb{E}_\theta \left[\nabla_\eta^2 \log p_\eta(X) \Big|_{\eta=\theta+t\delta} \right] dt = \frac{1}{2} \mathbb{E}_\theta \nabla_\theta^2 \log p_\theta(X) + o(1)$$

在有限维矩阵算子范数下成立. 代入信息恒等式, 左右乘 $\delta^\top, \delta$, 矩阵的 $o(1)$ 便成为 $o(\|\delta\|_2^2)$, 得到结论. ■

Fisher 总半正定, 但成为度量还需要得分满秩: 对每个 $\mathbf{v} \neq \mathbf{0}$, 都有 $\mathbb{E}_\theta(\mathbf{v}^\top \mathbf{s}_\theta)^2 > 0$. 这恰好等价于 $\mathbf{F}(\theta)$ 正定; 从切向量看, 没有非零参数方向在一阶上完全不改变分布. 局部可识别只排除附近参数产生同一分布, 不能代替这个微分条件. 例如 $P_\theta = \mathcal{N}(\theta^3, \sigma^2)$ 的参数表示一一对应, 但

$$F(\theta) = 9\theta^4/\sigma^2, \quad D_{\text{KL}}(P_0 \| P_\delta) = \delta^6/(2\sigma^2).$$

在零点 Fisher 为零, KL 从六阶才开始变化; “不同参数可区分” 不等于 “每个方向都有非零二阶曲率”。

定义 11.30 Fisher 度量 在 Fisher 矩阵正定的正则参数点, 对切向量 $\mathbf{u}, \mathbf{v}$ 定义 Fisher 度量

$$g_\theta(\mathbf{u}, \mathbf{v}) = \mathbf{u}^\top \mathbf{F}(\theta) \mathbf{v}.$$

高斯位置族的 $F(\mu) = 1/\sigma^2$, 局部长度为 $|\mathrm{d}\mu|/\sigma$, 与均值移动的 KL 公式一致。Bernoulli 族 $P_p, 0 < p < 1$ 的得分在结果 1, 0 上分别为 $1/p, -1/(1-p)$, 故

$$F(p) = p/p^2 + (1-p)/(1-p)^2 = \frac{1}{p(1-p)}.$$

固定 $p = 0.2$, 精确 KL 为 $0.2 \log(0.2/q) + 0.8 \log(0.8/(1-q))$, 二阶式为 $(q - 0.2)^2/0.32$ 。在 $q = 0.22$ 处二者约为 0.00119, 0.00125; 当 $q \downarrow 0$ 时精确 KL 无限, 固定二次式却仍有限。图 11.6 同时显示邻域近似和远离邻域后的差别, 不能把局部度量当成全域散度。




图 11.6 Bernoulli 族在 $p = 0.2$ 处的 Fisher 局部近似（解析式教学图）。蓝实线为 $D_{\text{KL}}(P_{0.2}||P_q)$, 红虚线为 $(q - 0.2)^2/[2(0.2)(0.8)]$; 右图放大邻域。图中 $0 < q < 1$, 二阶式只描述足够小的参数扰动。

重参数化下的几何保持 令 $\theta = \theta(\phi)$ 为光滑局部可逆坐标变换, Jacobian 为 $J = \partial\theta/\partial\phi$ 。在对应点 $P_\phi = P_{\theta(\phi)}$ 是同一张分布, 不是又施加一次统计扰动。链式法则给出

$$s_\phi = J^\top s_\theta, \quad F_\phi = J^\top F_\theta J.$$

因切向量满足 $\mathrm{d}\theta = J \mathrm{d}\phi$,

$$\mathrm{d}\phi^\top F_\phi \mathrm{d}\phi = \mathrm{d}\theta^\top F_\theta \mathrm{d}\theta.$$

对同一标量目标 L , 梯度坐标变为 $g_\phi = J^\top g_\theta$, 因此目标微分 $g_\phi^\top \mathrm{d}\phi = g_\theta^\top \mathrm{d}\theta$ 也不变。Fisher 矩阵的数值会变, 不变的是它作用于对应切向量所得到的二次型。

例如 Bernoulli 概率 p 改用 logit 坐标 $\phi = \log[p/(1-p)]$, $dp/d\phi = p(1-p)$, 于是

$$F_\phi = \{p(1-p)\}^2 F_p = p(1-p).$$

一个坐标下的 Fisher 在边界附近变大, 另一个变小, 但对同一分布扰动, $(dp)^2/[p(1-p)] = p(1-p)(d\phi)^2$. 坐标变换退化时不在上述局部可逆范围, 例如立方高斯例子在零点的 Jacobian 为零。

在序贯模型中, 必须先说明要衡量哪一种分布的变化, 再构造 Fisher 矩阵。固定状态 s , 策略 $\pi_\theta(a | s)$ 的单步 Fisher 为

$$\mathbf{F}_s(\theta) = \mathbb{E}_{A \sim \pi_\theta(\cdot | s)}[\mathbf{s}_\theta(s, A)\mathbf{s}_\theta(s, A)^\top].$$

若状态访问权重 $d(s)$ 被指定并保持固定, 平均矩阵为 $\mathbf{F}_d = \mathbb{E}_{S \sim d} \mathbf{F}_S$ 。它衡量的是: 保持状态分布 d 不变时, 各状态下动作概率的变化。若把 $d_\theta(s)\pi_\theta(a | s)$ 作为完整联合模型求导, 得分还包含 $\nabla \log d_\theta(s)$ 。在正则条件下, 条件策略得分均值为零, 交叉项消失, 联合 Fisher 成为

$$\mathbf{F}_{d_\theta \pi_\theta} = \mathbf{F}_{d_\theta}^{\text{state}} + \mathbb{E}_{d_\theta} \mathbf{F}_S.$$

它与把当前访问权重固定后得到的平均矩阵不是同一个对象。

第三个对象是完整轨迹 Fisher。设初始分布和环境转移都不依赖参数, 参数只出现在固定有限时域 T 的条件动作核中。假设共同支持和交换微分成立, 各步得分二阶可积。轨迹得分为 $\sum_{t=1}^T \mathbf{s}_t$, 其中 $\mathbb{E}[\mathbf{s}_t | H_t] = \mathbf{0}$, H_t 为选择动作前的历史。当 $u < t$ 时, $\mathbf{s}_u$ 对 H_t 可测, 因此

$$\mathbb{E}[\mathbf{s}_u \mathbf{s}_t^\top] = \mathbb{E}[\mathbf{s}_u \mathbb{E}(\mathbf{s}_t^\top | H_t)] = \mathbf{0}.$$

展开外积便得到

$$\mathbf{F}_{\text{trajectory}} = \sum_{t=1}^T \mathbb{E}[\mathbf{F}_{H_t}],$$

而不是某个任意固定访问分布下的单步矩阵。Markov 策略下可把条件矩阵写成 $\mathbf{F}_{S_t}$; 若访问权重取各时刻边缘的平均, 轨迹矩阵等于对应平均矩阵的 T 倍。环境或初始规律也含参数时, 必须加入它们的得分, 不能沿用策略独占参数的公式。

另一个常见混淆发生在样本矩阵与模型期望之间。固定输入分布 d ，取条件高斯 $Y | \mathbf{X} = \mathbf{x} \sim \mathcal{N}(\theta^\top \mathbf{x}, \sigma^2)$ ，其中 $\sigma > 0$ 已知， $\mathbb{E}_d \|\mathbf{X}\|^2 < \infty$ 。同一观测的三个量为

$$\begin{aligned} \mathbf{s}_\theta(\mathbf{x}, y) &= \frac{y - \theta^\top \mathbf{x}}{\sigma^2} \mathbf{x}, \\ -\nabla_\theta^2 \log p_\theta(y | \mathbf{x}) &= \frac{\mathbf{x} \mathbf{x}^\top}{\sigma^2}, \\ \mathbf{s}_\theta \mathbf{s}_\theta^\top &= \frac{(y - \theta^\top \mathbf{x})^2}{\sigma^4} \mathbf{x} \mathbf{x}^\top. \end{aligned}$$

按当前模型的条件分布平均时，残差平方期望为 σ^2 ，后两个矩阵的条件期望相同，再按 d 平均得到 $\mathbf{F} = \mathbb{E}_d[\mathbf{X} \mathbf{X}^\top] / \sigma^2$ 。对一条样本，它们并不相等；残差为零时，得分外积甚至为零，而非零输入的观测 Hessian 不为零。如果真实响应规律不同于当前模型，残差平方的条件期望也可能不同，经验得分外积的总体极限便不一定等于这个模型 Fisher。改变输入权重、使用观测 Hessian 或经验得分外积，都须重新说明正在近似哪个对象。

11.4.3.2 局部度量下的几何更新

有了局部长度和目标微分，就可以确定在给定分布变化预算内怎样下降。这仍是原优化任务的局部求解步骤：若参数表示有约束，应在相应可行切空间中求解，或结合约束优化和回缩；Fisher 矩阵本身不会自动保持矩与固定边缘。

分布变化约束下的自然梯度 设目标 $L(\theta)$ 可微， $\mathbf{g} = \nabla L(\theta)$ ，且 $\mathbf{F}(\theta)$ 正定。以欧氏参数长度限制步幅时，负梯度给出目标下降最快的方向；若某个方向的参数移动会引起更大的分布变化，就应把它的移动代价计入方向选择。Fisher 内积给出这项局部代价，相应的梯度由下面的定义确定⁴。

定义 11.31 自然梯度 目标 L 的自然梯度 (natural gradient) 是满足

$$g_\theta(\text{grad}^F L, \mathbf{v}) = \nabla L(\theta)^\top \mathbf{v} \quad \text{对所有切向量 } \mathbf{v}$$

的唯一向量，即 $\text{grad}^F L = \mathbf{F}(\theta)^{-1} \nabla L(\theta)$ 。

把目标一阶线性化，把分布 KL 变化二阶近似，得到局部信赖域子问题

$$\min_{\boldsymbol{\delta}} \mathbf{g}^\top \boldsymbol{\delta} \quad \text{s.t.} \quad \frac{1}{2} \boldsymbol{\delta}^\top \mathbf{F}(\theta) \boldsymbol{\delta} \leq \varepsilon. \quad (11.48)$$

⁴S.-i. Amari, *Natural Gradient Works Efficiently in Learning* In *Neural Computation*, 1998, vol. 10, no. 2, pp. 251–276

设 $\varepsilon > 0, \mathbf{g} \neq \mathbf{0}$ 。Lagrangian 为 $\mathbf{g}^\top \boldsymbol{\delta} + \lambda(\boldsymbol{\delta}^\top \mathbf{F} \boldsymbol{\delta} / 2 - \varepsilon)$ ，驻点条件给出 $\mathbf{g} + \lambda \mathbf{F} \boldsymbol{\delta} = \mathbf{0}$ 。非零线性目标的最小值在椭圆边界，代入 $\boldsymbol{\delta} = -\lambda^{-1} \mathbf{F}^{-1} \mathbf{g}$ 得到 $\lambda = \sqrt{\mathbf{g}^\top \mathbf{F}^{-1} \mathbf{g} / (2\varepsilon)}$ ，所以

$$\boldsymbol{\delta}^* = -\sqrt{\frac{2\varepsilon}{\mathbf{g}^\top \mathbf{F}^{-1} \mathbf{g}}} \mathbf{F}^{-1} \mathbf{g}. \quad (11.49)$$

可以不依赖驻点必要条件，直接验证全局最优性。令 $\mathbf{u} = \mathbf{F}^{1/2} \boldsymbol{\delta}$ ，约束变为 $\|\mathbf{u}\|_2 \leq \sqrt{2\varepsilon}$ ，目标变为 $(\mathbf{F}^{-1/2} \mathbf{g})^\top \mathbf{u}$ 。Cauchy-Schwarz 给出

$$(\mathbf{F}^{-1/2} \mathbf{g})^\top \mathbf{u} \geq -\|\mathbf{F}^{-1/2} \mathbf{g}\|_2 \sqrt{2\varepsilon}.$$

等号在 $\mathbf{u}$ 与 $-\mathbf{F}^{-1/2} \mathbf{g}$ 同向并位于球面时达到，代回正好得到上述解。若 $\mathbf{g} = \mathbf{0}$ ，一阶目标处处为零，子问题不再选出唯一方向，应考察高阶信息或停止条件。

示例 11.32 同一分布变化预算下的两个下降方向 设在当前参数点，局部 Fisher 矩阵与目标梯度为

$$\mathbf{F} = \begin{pmatrix} 100 & 0 \\ 0 & 1 \end{pmatrix}, \quad \mathbf{g} = \begin{pmatrix} 1 \\ 1 \end{pmatrix}.$$

目标的一阶变化为 $\delta_1 + \delta_2$ ，但同样大小的第一维位移消耗的二次 KL 预算是第二维的 100 倍。取局部预算 $\varepsilon = 0.005$ ，可行椭圆为 $100\delta_1^2 + \delta_2^2 \leq 0.01$ 。普通欧氏下降方向是 $-\mathbf{g}$ ，自然下降方向是 $-\mathbf{F}^{-1} \mathbf{g} = -(0.01, 1)^\top$ 。为公平比较，把两个方向都缩放到同一椭圆边界，得到

$$\boldsymbol{\delta}_E = -\frac{0.1}{\sqrt{101}}(1, 1)^\top, \quad \boldsymbol{\delta}_F = -\frac{0.1}{\sqrt{1.01}}(0.01, 1)^\top.$$

两者都恰好消耗 0.005 的二次预算，目标的一阶下降量分别为

$$-\mathbf{g}^\top \boldsymbol{\delta}_E = \frac{0.2}{\sqrt{101}} \approx 0.0199, \quad -\mathbf{g}^\top \boldsymbol{\delta}_F = 0.1\sqrt{1.01} \approx 0.1005.$$

自然方向减少昂贵的第一维移动，把更多预算用于第二维，因此在当前局部模型中获得更大的下降量。这里 $\mathbf{F}$ 刻画分布变化的局部代价，不是一般目标 L 的 Hessian；上述数值比较的是线性化目标与二次 KL 模型，不能直接当作真实目标的有限步下降保证。

图 11.7 把两个缩放后的方向放在同一预算边界上。两轴采用相同的物理尺度，细长椭圆说明第一维允许的位移更小。




图 11.7 局部 KL 预算下的下降方向（解析式教学图）。灰色椭圆满足 $100\delta_1^2 + \delta_2^2 = 0.01$ ，对应 $\varepsilon = 0.005$ 。蓝色虚线与圆点是缩放后的欧氏方向 δ_E ，红色实线与方点是自然方向 δ_F ；两个终点消耗相同的二次预算。椭圆表达分布变化代价，不是目标函数的等高线。

在光滑可逆重参数化下，由上一小节的矩阵和微分变换，

$$\begin{aligned} JF_\phi^{-1}g_\phi &= J(J^\top F_\theta J)^{-1}J^\top g_\theta \\ &= F_\theta^{-1}g_\theta. \end{aligned}$$

归一化因子中的 $g_\phi^\top F_\phi^{-1}g_\phi$ 也等于原坐标下的相应值，因此两个坐标给出同一个分布切向方向。Bernoulli 例子中，自然梯度在概率坐标为 $p(1-p)L'(p)$ ，在 logit 坐标为 $L'(p)$ ；乘上 $dp/d\phi = p(1-p)$ 后相同。

保持的是无穷小方向，不是任意有限离散步。非线性坐标映射下， $\theta(\phi + \delta_\phi) = \theta(\phi) + J\delta_\phi + O(\|\delta_\phi\|^2)$ ，所以分别做欧氏加法更新后的终点一般不同。真实 KL 也还有 $o(\|\delta\|^2)$ 余项；二次预算等于 ε 不保证真实 KL 严格不超过它。有限步需要步长选择、真实目标或 KL 检查，不能由局部方向不变性直接得到全局改进。

奇异与近似条件下的几何更新 参数冗余、退化坐标或不足的输入方向都可能使 Fisher 奇异。若方向位于 Fisher 的零空间，沿该方向的一阶得分为零：有时它来自完全冗余，有时如立方高斯零点，只是高阶变化未被二次型看见。因而不能把所有零方向都理解成有限移动后分布完全不变。

回用伪逆与数值求解工具，若 $g \in \text{range}(F)$ ，线性方程 $Fv = g$ 有解，全部解为

$$v = F^\dagger g + z, \quad z \in \ker F.$$

伪逆选择当前欧氏坐标下范数最小的一个。如果只比较一阶分布变化，那么相差一个零空间向量的参数方向视为相同，这便得到切向商空间。零空间分量不影响这一阶变化，但参数向量并不唯一，有限步的高阶效果仍可能不同。若 $\mathbf{g} \notin \text{range}(\mathbf{F})$ ，存在零方向 $\mathbf{z}$ 使 $\mathbf{g}^\top \mathbf{z} \neq 0$ ；沿其下降方向任意放大仍不消耗二次预算，线性信赖域问题无下界。此时简单写 $\mathbf{F}^\dagger \mathbf{g}$ 不是原信赖域子问题的解，必须修正退化模型或约束。

阻尼使用 $\mathbf{F} + \lambda \mathbf{I}$ ，其中 $\lambda > 0$ ，可改善病态性并保证可逆。但它新增欧氏二次项 $\lambda \|\delta\|^2$ ，不是纯粹的 Fisher 几何：一般坐标变化下

$$\mathbf{J}^\top (\mathbf{F} + \lambda \mathbf{I}) \mathbf{J} = \mathbf{J}^\top \mathbf{F} \mathbf{J} + \lambda \mathbf{J}^\top \mathbf{J} \neq \mathbf{F}_\phi + \lambda \mathbf{I}.$$

因此“能稳定求逆”与“保持原坐标变换性质”是不同要求。实际计算通常求解线性系统，而不显式构造逆矩阵；迭代容差、谱条件和矩阵近似误差也会改变得到的方向。

经验 Fisher、分块或对角近似可能降低计算量，却分别引入抽样、模型期望或跨块相关性的近似。即使每个近似矩阵都正定，也只说明定义了某种局部内积，不说明它等于真实分布 Fisher，更不保证同样的坐标保持结论。应区分模型下期望、真实数据下平均、固定输入权重和完整轨迹，再说明哪一项被估计或省略。优化收敛、模型正确性、预测校准和隐私保证还各有自己的条件；自然梯度或 KL 正则不能把一种保证自动转成另一种。

11.5 本章小结

开篇的编码与预测问题对应两个不同对象。熵平均单个结果的自信息，条件熵记录已有观测后还需描述的部分；交叉熵把预测规律放到真实规律下评价，多出的对数代价是有方向的 KL。互信息则比较联合分布与独立乘积，带噪二元例子显示观测究竟减少了多少不确定性。连续情形必须指定参考测度，微分熵的坐标变化不能与 KL 的坐标不变性混为一谈。

比较两张分布时，要先说明希望看见什么差别。总变差控制事件概率差，MMD 控制所选核空间中的函数期望差，Wasserstein 比较概率质量移动的距离；Rényi 通过密度比高阶矩限制换分布后事件概率的放大。相同均值可以掩盖分布差异，点质量的小位移可以保持平滑评价稳定，却使阈值事件完全改变。因此小距离只有结合取值范围、敏感性或尾部条件，才能变成具体任务保证。如果预测器根据评价数据选择，还需要处理选择带来的依赖：互信息控制先平均、后取绝对值的泛化差，PAC-Bayes 则在先验和分析参数预先固定时同时控制全部候选分布的风险。

信息不足也给出反向限制。Le Cam 与 Fano 要求同时构造目标分离、观测接近的候选，自适应观测则沿实际历史累计条件信息，不能当作固定设

计的独立样本。这些结论限制任何算法能够知道什么，不等于某个算法已经达到下界。

分布优化又把比较量变成目标或约束。Gibbs 倾斜权衡收益和 KL 偏离，最大熵从给定矩中选择相容分布，ELBO 在表示受限的候选族中逼近后验；固定边缘的搬运问题只选择联合配对。有限配置的负最大熵与配分函数共轭在边界仍成立，但分布最优解不一定有有限参数表示。最优耦合依赖紧性与成本下半连续，后验逼近依赖明确方向的支持条件。

参数化求解时，正则满秩模型的局部 KL 给出 Fisher 度量，自然梯度据此选择同一分布切向方向。奇异性、阻尼、矩阵近似与有限步余项都限制这一结论的直接使用。局部几何不能替代全域散度，优化替代分布也不能替代真实数据证据。若问题从观测规律转为干预会怎样改变结果，还需要第 12 章的生成机制与识别条件。

因果响应

接受培训的人平均成绩更高，是培训提高了成绩，还是基础较好的人更愿意参加培训？第 10 章已经建立条件分布与统计推断，第 11 章进一步比较分布及其对任务的影响。但把成绩预测得很准，仍不能回答主动安排培训以后会发生什么。后一个问题要求说明：改变的究竟是对已有记录的筛选，还是产生记录的机制。

本章沿着培训问题追问两件事：给同一个人安排不同的培训，会得到什么结果？培训又是通过哪些环节影响成绩的？前一问需要描述行动后的结果，后一问需要说明技能、时间等变量之间的生成关系。我们以处理 T 、结果 Y 与处理前信息 X 为共同例子，区分给定模型的计算、数据对响应的识别，以及数据对生成结构的推断。模型明确给定时，可以直接比较行动，也可以在得知某人的事实以后计算替代结果；这不意味着数据已经证明该模型正确。反过来，有些平均响应可以由实验设计识别，而无须唯一恢复每一个局部方程。

本章先假定模型已经给定，说明行动怎样改变结果，再比较个人、人群和小幅剂量变化。如果知道某人的实际记录，就先用这些记录推断他的背景，再计算替代行动的结果。随后检查：手中的数据是否足以确定这些答案？最后再把整体模型拆成局部方程，说明怎样逐步生成结果，以及图中的箭头为何具有因果含义。贯穿全章的区别是：给定一套模型可以算出答案，并不意味着现有数据已经排除了其他答案。

12.1 因果响应的表示

要询问一个人接受培训后的成绩，至少需要说明培训方案、这个人的背景、成绩测量时间，以及安排培训会改变哪些生成规则。只给出一个拟合函数 $E[Y | T = t, X = x]$ 还不够：它描述自然分配下的条件平均，未必描述主动安排培训的后果。本节先说明回答这类问题必须给定哪些信息，随后才展开模型内部的结构。

12.1.1 原因与背景的响应表示

用 t 表示可以设定的处理值，用 $\mathbf{u}$ 表示在所比较行动之间保持的个体背景。背景包含模型没有继续解释的差异，例如既有能力和未测量的环境因素；它与“所有已观测协变量”不是同义词。模型 M 规定背景的联合分布、自然运行规则和允许的行动。本节先假定：一旦指定背景和行动，这些规则就能给出唯一结果。后面再说明怎样用局部方程保证这一点。

定义 12.1 因果响应与自然、行动映射 给定背景可测空间 $(\mathcal{U}, \mathcal{U})$ 及概率测度 P_U ，自然变量的可测状态空间 $\mathcal{V}$ ，处理空间 $\mathcal{T}$ 和结果空间 $\mathcal{Y}$ 。固定模型 M 提供取值唯一的可测自然映射 $F_M : \mathcal{U} \rightarrow \mathcal{V}$ ，以及每个允许行动 a 的取值唯一的可测映射 $F_M^a : \mathcal{U} \rightarrow \mathcal{V}$ 。后者由模型指定的机制替换产生，而非任意另选函数。若 $a(t)$ 表示把处理设为 t 的允许行动， π_Y 表示取结果坐标，则因果响应 (causal response) 是映射

$$R_M : \mathcal{T} \times \mathcal{U} \longrightarrow \mathcal{Y}, \quad R_M(t, \mathbf{u}) = \pi_Y(F_M^{a(t)}(\mathbf{u})). \quad (12.1)$$

本章要求 R_M 对乘积可测结构可测。自然变量为 $\mathbf{V} = F_M(\mathbf{U})$ ，行动后的变量为 $\mathbf{V}_a = F_M^a(\mathbf{U})$ 。

固定 $\mathbf{u}$ 时， $t \mapsto R_M(t, \mathbf{u})$ 回答同一单位怎样响应不同处理；让 $\mathbf{U}$ 按 P_U 变化，才得到总体响应分布。外生背景的各分量可以相关，定义没有默许独立性。若采用有限维参数表示 M_θ ，参数 θ 描述研究者选定的机制；修改拟合参数是在改变模型，设置 t 则是在一个固定模型内行动。两种变化不能互相代替。

为了看清相同的观测记录为何可能对应不同的行动后果，下面构造两套二元机制。用 $T = 1$ 表示参加培训，用 $Y = 1$ 表示成绩达标。设背景满足

$$U \sim \text{Bernoulli}(1/2).$$

处理与结果均取 0, 1。模型甲为

$$T = U, \quad Y = U; \quad (12.2)$$

模型乙为

$$T = U, \quad Y = T. \quad (12.3)$$

两者自然映射都是 $F_M(u) = (u, u)$ ，从而

$$\mathbb{P}(T = 0, Y = 0) = \mathbb{P}(T = 1, Y = 1) = \frac{1}{2},$$

$$\mathbb{P}(T = 0, Y = 1) = \mathbb{P}(T = 1, Y = 0) = 0.$$

在甲中，处理不进入结果规则；在乙中，结果直接复制处理。若允许的行动是把处理规则替换为常数 t ，保留结果规则，则

$$F_{M_{\text{甲}}}^{a(t)}(u) = (t, u), \quad F_{M_{\text{乙}}}^{a(t)}(u) = (t, t),$$

所以 $R_{M_{\text{甲}}}(t, u) = u$ ，而 $R_{M_{\text{乙}}}(t, u) = t$ 。两模型的自然映射相同，行动映射不同；即使观察到无限多条按自然规则产生的记录，也无法区分这两种行动后果，因为两模型给出的观测分布完全相同。

12.1.2 机制干预下的潜在结果

上例没有筛出自然接受处理的人，而是改变了处理怎样产生。这就是机制干预：指定一项生成规则的替换，再让其余规则根据新的输入继续运行。行动的因果含义来自这种替换约定，不来自函数名称或概率记号。

定义 12.2 理想干预 对给定模型的处理变量 T 作干预 (intervention) $\text{do}(T = t)$ ，表示删除自然生成 T 的规则，并以常量规则 $T = t$ 替换。其余生成规则和指定的背景分布 P_U 保持不变。由行动映射 $F_M^{a(t)}$ 推前得到的分布记作 $P^{\text{do}(T=t)}$ 。

“其余规则不变”不是说其余变量的取值不变。若培训改变技能，技能再影响成绩，行动后技能和成绩都应重算。只改培训字段、把技能等其他字段全部固定，再评估一个预测器，通常不能代表真实安排培训后的结果。多变量行动同样由 F_M^a 表达，但模型必须说明哪些规则替换、哪些保留。

定义 12.3 潜在结果 对明确的目标总体、处理版本和结果测量时间，潜在结果 (potential outcome) 是随机变量

$$Y(t) = R_M(t, U). \quad (12.4)$$

对二元处理， $(Y(0), Y(1))$ 定义在同一背景概率空间上；两项分别表示同一单位在两种处理下的结果，而不是分别抽取两个人。

可测性保证可以讨论潜在结果的概率规律。记 $\mathcal{L}(Z)$ 为随机变量 Z 的分布，则

$$\mathcal{L}(Y(t)) = (R_M(t, \cdot))_{\#} P_U = \mathcal{L}(Y \mid \text{do}(T = t)).$$

符号 $\#$ 表示第 10.3.1.1 节的分布推前。这里的 do 标记修改后的模型，不是对自然事件 $T = t$ 作普通条件化。潜在结果聚焦所选行动下的输出；仅有一张潜在结果表，并不自动给出其他变量的完整生成机制¹。

¹ M. A. Hernán, J. M. Robins, *Causal Inference: What If*, Chapman & Hall/CRC, 2020

观察条件分布 $p(y | T = t)$ 会筛选自然规则恰好给出处理 t 的单位，因而同时包含处理作用和进入处理组的选择。在上面两套机制中，都有

$$\mathbb{P}(Y = 1 | T = 1) = 1, \quad \mathbb{P}(Y = 1 | T = 0) = 0.$$

但对甲，设定处理以后结果仍为 U ，故

$$\mathbb{P}(Y = 1 | \text{do}(T = t)) = \frac{1}{2}, \quad t \in \{0, 1\};$$

对乙，设定处理以后结果为 t ，故

$$\mathbb{P}(Y = 1 | \text{do}(T = t)) = t.$$

两模型都能完全解释“参加者成绩较高”的观测现象，但对安排培训给出不同答案。要区分它们，需要关于结果怎样生成的额外信息；把这两个相同的条件概率估计得更准，仍然无法解决问题。

固定处理值并非唯一行动。随机干预（stochastic intervention）用新的随机规则替换处理规则，例如给定处理前信息 $X = x$ 时，按 $q(t | x)$ 安排培训。一种明确构造是加入独立于原背景的随机量 W ，指定 $T = g_q(X, W)$ ，使其条件分布为 $q(\cdot | X)$ ，再运行保留的机制。确定性策略是新规则不再需要随机化的特例。随机化是否独立、行动可使用哪些信息，都是干预定义的一部分；仅把某个概率因子改写为 q 不能保证其余现实机制未变。局部机制成立时相应的分解公式在第 12.5.2 节建立。

12.1.3 观测结果与干预响应的连接

有了两种行动下的结果，还要说明实际观察到的成绩对应哪一种行动。为此必须先固定研究对象、具体培训方案和成绩测量时间。若这些约定没有固定，同一个“接受培训”可能混合不同课程与时长， $Y(1)$ 就未必是一个确定的对象。

定义 12.4 处理一致性与无干扰 对明确的处理版本，一致性（consistency）要求实际处理对应的结果满足 $Y = Y(T)$ 几乎必然成立；特别地，

$$\begin{aligned} T = t &\implies Y = Y(t), \\ \text{二元处理时, } Y &= TY(1) + (1 - T)Y(0). \end{aligned} \tag{12.5}$$

对 n 个单位，无干扰要求：每个 i 及任意两个处理向量 $\mathbf{t}, \mathbf{t}'$ ，只要 $t_i = t'_i$ ，就有 $Y_i(\mathbf{t}) = Y_i(\mathbf{t}')$ 几乎必然成立。因此单位 i 的潜在结果才可简记为 $Y_i(t_i)$ 。

一致性连接自然记录与行动响应，没有把未采取行动的结果变成可见记录。若模型给出自然处理 $T = F_{M,T}(\mathbf{U})$ ，就必须保证：把这个实际处理值代入响应函数，得到的仍是实际结果，即 $R_M(F_{M,T}(\mathbf{U}), \mathbf{U})$ 与自然结果相同。不能把一套自然生成规则与另一套互不相容的行动规则拼在一起。在依规则替换而构造的无环模型中，这种相合性可以逐方程检查。

无干扰则限制研究单位之间的相互作用。疫苗接种、社交网络和市场竞中，一人的行动可能改变他人的暴露或机会；此时 $Y_i(\mathbf{t})$ 往往依赖整个处理向量。例如 $Y_i(\mathbf{t}) = t_i + \eta \sum_{j \neq i} t_j / (n-1)$ 在 $n > 1, \eta \neq 0$ 时不满足无干扰。可以另行规定网络暴露、分组方案或总体处理比例，但不能继续把只比较 t_i 的效应解释为所有联动后果。

通常所说的稳定单位处理值假设把处理版本唯一性和无干扰合在一起。它们与分配机制仍须分开判断：分配机制规定 T 怎样依赖 $X, Y(0), Y(1)$ 等量，一致性只连接实际处理与观察结果。即使处理版本清楚且单位互不干扰，主动选择培训的人也可能具有不同背景。响应的表示到此已建立，能否由这种选择后的观测恢复响应，是后面识别部分的问题。

12.2 因果响应的比较与变化

同一项培训可以提高平均成绩，却使一部分人的成绩下降；它也可能不改变均值，只减少低分结果。因而“有没有效”必须落实为具体比较。本节固定模型、目标总体和处理版本，分别比较同一背景的两个结果、背景总体的平均与分布，以及连续剂量的局部变化。

12.2.1 同一背景下的响应比较

要判断培训对某个人的作用，应比较这个人参加和不参加时的成绩。两次比较必须保留相同的既有背景，否则差值还会混入人与人之间原本就有的差异。

定义 12.5 同一背景下的响应差 对实值结果及允许的处理值 t, t' ，固定背景 $\mathbf{u}$ 的响应差定义为

$$\Delta_M(t, t'; \mathbf{u}) = R_M(t, \mathbf{u}) - R_M(t', \mathbf{u}). \quad (12.6)$$

二元处理的个体处理效应 (individual treatment effect) 是随机变量 $Y(1) - Y(0) = \Delta_M(1, 0; \mathbf{U})$ 。

这里的减法保持同一背景，而不是用一个处理组成员减去另一个未处理组成员。例如 $R_M(t, \mathbf{u}) = u + (2u - 1)t$ ，其中 $u \in \{0, 1\}$ 。对背景 $u = 1$,

处理使结果增加 1；对 $u = 0$ ，处理使结果减少 1。比较两名不同背景个体的实际结果，还混入了基础值 u 的差异。

给定模型和背景时，两个响应都可以计算。但每个单位的实际记录只能包含 $Y(T)$ ，不会同时包含同一时刻的 $Y(1)$ 与 $Y(0)$ 。因此“个体效应有明确定义”与“它能由该人的一次观察确定”是两件事。即使已知某人当前结果为零，仍需要机制或关于背景的信息才能计算另一行动下的结果。

对向量结果，可以先报告各坐标差，也可以指定具有实质含义的效用函数 $h: \mathcal{Y} \rightarrow \mathbb{R}$ ，比较 $h(R_M(t, \mathbf{u})) - h(R_M(t', \mathbf{u}))$ 。对类别结果，直接相减通常没有意义，可以比较某事件的指示量。选择 h 是在规定目标，不是纯粹的记号替换：提高收入、降低风险和同时满足两项要求，可能给出不同的行动排序。

12.2.2 背景总体下的响应比较

实践中通常无法确定每个人的完整背景，但仍要决定是否向一群人提供培训。此时可以按目标人群的背景分布求平均，或者比较整个人群的成绩分布。前者回答平均收益，后者还能检查低分风险等均值看不到的变化。

12.2.2.1 总体与条件总体的平均响应比较

先问一个最直接的总体问题：如果目标人群都参加培训，其平均成绩会比都不参加时高多少？这需要对同一个人群比较两种安排。

定义 12.6 平均处理效应 对二元处理，假设 $Y(0), Y(1)$ 都可积，平均处理效应（average treatment effect, ATE）定义为

$$\tau = \mathbb{E}[Y \mid \text{do}(T = 1)] - \mathbb{E}[Y \mid \text{do}(T = 0)]. \quad (12.7)$$

两个干预总体使用同一个 P_U 。由潜在结果与干预分布的对应关系及期望线性性，

$$\tau = \mathbb{E}[Y(1) - Y(0)] = \mathbb{E}[Y(1)] - \mathbb{E}[Y(0)]. \quad (12.8)$$

可积性排除了 $\infty - \infty$ 这样的未定义运算。线性期望说明计算平均差只需要两个边缘均值，并没有使同一单位的两个结果同时可见。上例若 $\mathbb{P}(U = 1) = \mathbb{P}(U = 0) = 1/2$ ，ATE 为零，但没有人的个体效应为零。

若要辨认哪些人可能受益，可以在处理前协变量 X 下分层。

定义 12.7 条件平均处理效应 设 X 在所比较干预下保持同一取值与含义, 且两种潜在结果可积。条件平均处理效应 (conditional average treatment effect, CATE) 是

$$\tau(x) = \mathbb{E}[Y(1) - Y(0) | X = x], \quad P_X \text{ 几乎处处.} \quad (12.9)$$

它对具有相同已知特征的人平均, 不等于这些人逐个具有相同效应。取 $X = U$ 时, 上例的 $\tau(1) = 1, \tau(0) = -1$; 若 X 未包含 U , 条件平均仍可能掩盖层内差异。不能把处理后的技能水平直接当作这里不随行动变化的 X : 按两种行动各自产生的技能筛人, 通常不是比较同一条件总体。

全期望给出 $\tau = \mathbb{E}_X[\tau(X)]$ 。若响应机制不变而目标总体从 P_X 换为 Q_X , 且对应的条件背景规律与条件效应保持不变, 新 ATE 为 $\int \tau(x)Q_X(dx)$ 。这是人群权重的变化, 不是机制突然发生改变; 条件效应能否跨总体保留本身仍需假设。目标总体、处理版本或测量时间改变, 都应重新标明效应的含义。

对有限处理集合 $\mathcal{T}$, 同样定义

$$\tau(t, t') = \mathbb{E}[Y(t) - Y(t')].$$

若行动由处理前信息决定, 则要比整个策略。令有限动作集合为 $\mathcal{A}$, 策略 $\pi(a | x)$ 用独立的新增随机化, 在给定 $X = x$ 时选择动作 a 。在所有潜在结果可积时, 它的单步价值为

$$V(\pi) = \mathbb{E}_X \left[\sum_{a \in \mathcal{A}} \pi(a | X) \mathbb{E}[Y(a) | X] \right]. \quad (12.10)$$

式中独立随机化保证选择动作不会额外按未观测背景筛人。确定性策略是 π 集中于一个动作的特例。这里定义的是给定模型内的目标; 多值处理需要哪些观测覆盖、策略可使用哪些已有记录, 在第 12.4 节再检查。连续剂量也不能被当作每个精确值都具有正概率的离散组。

12.2.2.2 干预结果的分布响应比较

平均值只记录分布的一个特征。设 U 等概率取 $-1, 1$, $Y(0) = 0, Y(1) = U$, 则 ATE 为零, 但处理后从人人得到零变成两种相反结果。若低于零代表失败, 那么失败概率从 0 增加到 $1/2$ 。只报告 ATE 为零, 会漏掉这项风险。

对实值结果, 定义干预分布函数与其广义分位数

$$F_t(y) = \mathbb{P}(Y(t) \leq y), \quad Q_t(p) = \inf\{y : F_t(y) \geq p\}, \quad 0 < p < 1.$$

$F_t(y) - F_{t'}(y)$ 比较低于阈值的概率, $Q_t(p) - Q_{t'}(p)$ 比较两个总体处于同一分位位置的结果。后者并不是个体效应 $Y(t) - Y(t')$ 的第 p 分位数, 因为处于两个分布相同排名的未必是同一个人。只有额外规定跨行动的排序对应关系, 才能把这种配对解释成个体变化。

也可以使用第 11 章的分布比较尺度。总变差比较事件概率而不要求矩; 采用 p 阶 Wasserstein 距离时应满足所用空间和有限 p 阶矩条件; 使用 KL 散度则须检查绝对连续性及其值是否有限。应根据关心的风险或损失选择比较方式。均值差很小, 只说明平均值接近, 不能据此断言整个结果分布接近。

两个干预边缘即使完全已知, 仍没有说明它们如何在同一背景上配对。第 12.3.1 节将用两张联合表说明: 分布比较足以回答部分总体问题, 却不足以回答已知某人事实结果后的替代结果。

12.2.3 连续处理下的局部响应变化

二元处理适合比较有无行动; 连续剂量还可以询问“在当前剂量附近再增加一点会怎样”。这时回用第 3.3.2 节的局部线性近似, 但求导对象必须是固定模型、固定背景下的响应。

定义 12.8 局部响应导数 设处理取值位于开集 $\mathcal{T} \subseteq \mathbb{R}^k$, 结果位于 $\mathbb{R}^m$ 。用粗体标明向量剂量; 若 $\mathbf{t} \mapsto R_M(\mathbf{t}, \mathbf{u})$ 在 $\mathbf{t}_0$ 可微, 其局部响应 Jacobian 为 $D_{\mathbf{t}}R_M(\mathbf{t}_0, \mathbf{u})$, 满足

$$R_M(\mathbf{t}_0 + \mathbf{h}, \mathbf{u}) - R_M(\mathbf{t}_0, \mathbf{u}) = D_{\mathbf{t}}R_M(\mathbf{t}_0, \mathbf{u})\mathbf{h} + o(\|\mathbf{h}\|).$$

标量处理、标量结果时记为 $\partial_t R_M(t_0, \mathbf{u})$ 。

该导数是每单位剂量的局部变化, 不是任意有限剂量差。比如 $R_M(t, u) = u + t^2$, 从 $t = 1$ 增加到 $1 + h$ 的响应差是 $2h + h^2$, 局部导数为 2。 h 很小时一阶项有用, 但从 1 变到 2 的差为 3, 不能直接用导数值 2 代替。离散行动没有这样的邻域, 仍应使用有限差。

总体平均响应 $m(t) = \mathbb{E}[R_M(t, \mathbf{U})]$ 还包含积分, 不能仅凭每个人的响应可微就交换求导与期望。下面给出一个可以直接检查的充分条件。

定理 12.9 平均响应的求导 设 I 是包含 t_0 的开区间, $R_M(t_0, \mathbf{U})$ 可积。若对几乎每个 $\mathbf{u}$, $R_M(\cdot, \mathbf{u})$ 在 I 可微, 且存在非负可积函数 $g(\mathbf{U})$, 使

$$|\partial_t R_M(t, \mathbf{u})| \leq g(\mathbf{u}), \quad t \in I,$$

则 m 在 t_0 可微, 且

$$m'(t_0) = \mathbb{E}[\partial_t R_M(t_0, \mathbf{U})]. \quad (12.11)$$

证明. 对足够小的非零 h , 中值定理给出

$$\left| \frac{R_M(t_0 + h, \mathbf{u}) - R_M(t_0, \mathbf{u})}{h} \right| \leq g(\mathbf{u}).$$

因而 $R_M(t_0 + h, \mathbf{U})$ 可积, 且差商几乎处处收敛到 $\partial_t R_M(t_0, \mathbf{U})$ 。可积的 g 统一控制这些差商, 支配收敛定理允许将极限移入期望, 得到

$$\lim_{h \rightarrow 0} \frac{m(t_0 + h) - m(t_0)}{h} = \mathbb{E} \left[\lim_{h \rightarrow 0} \frac{R_M(t_0 + h, \mathbf{U}) - R_M(t_0, \mathbf{U})}{h} \right],$$

即所述结论。 ■

向量处理可以在相应可积控制下逐坐标求导; 若要得到完整可微性, 则需足以控制 Jacobian 及余项的邻域条件。上述定理把“个体可微”与“可交换积分”分开, 后者限制少量背景下异常陡峭的响应, 避免其破坏总体极限。

局部因果导数也不等于观测回归斜率 $\partial_t \mathbb{E}[Y \mid T = t, X = x]$ 。后者随 t 改变的还可能是自然进入该剂量的人群; 第 12.4.2.3 节将明确计算这种偏差。它同样不同于随机轨道的 Itô 微分: 这里对可设定输入作普通局部变化, 背景固定; 随机轨道微分描述随时间累积的随机变化, 一般不存在普通逐轨道时间导数。因此模型的光滑性支持局部计算, 却不同时保证这个导数能由观测识别或能外推到大幅行动。

12.3 给定事实后的因果响应

总体比较按目标背景分布平均; 若已知某人的成绩、处理和其他事实, 这些信息应当参与计算。例如, 已知某人没有参加培训且成绩未达标, 现在要问: 如果给这个人安排培训, 他的成绩会怎样? 他的已有成绩提供了背景信息, 因而不能直接套用随机抽取一个人的总体结果。本节仍固定模型, 只用事实更新对背景的认识, 再在同一背景上比较替代行动。

12.3.1 事实条件下的反事实计算

定义 12.10 给定响应模型的反事实变量 设模型 M 具有定义 12.1 的自然映射 F_M 及行动映射 F_M^a 。在同一外生背景 U 上, 反事实 (counterfactual) 变量定义为 $V_a = F_M^a(U)$ 。给定实际证据 E 后的反事实分布是 V_a 关于该证据的条件分布, 而不是重新按背景总体抽取一个人。

事实证据可以是实际成绩等自然变量, 也可以是带噪声的测量; 后一情形需要把测量的随机性也纳入背景, 说明这条证据怎样产生。反事实计算由三步组成: 先根据记录判断哪些背景更可能, 再替换行动规则, 最后让这些可能的背景通过新规则产生结果。三步通常称为“溯因、干预、预测”。第一步是在给定模型内更新背景分布, 并不是用一条记录证明模型正确。

设空间允许选取正则条件分布 $P_{U|E=e}$, 例如本章常用的标准 Borel 空间。回用第 10.2.2.2 节, 对任意可测集合 B , 三步合成为

$$\begin{aligned}\mathbb{P}(V_a \in B \mid E = e) &= ((F_M^a)_\# P_{U|E=e})(B) \\ &= \int \mathbb{I}\{F_M^a(u) \in B\} P_{U|E=e}(du).\end{aligned}\quad (12.12)$$

式中, 事实证据决定使用哪一个背景条件分布, 行动决定用哪一个生成映射。连续变量恰好等于某个证据值的概率通常为零, 等式按所选正则条件分布版本理解, 只保证对证据分布几乎处处的 e 成立。在一个指定的零概率证据点上报告数值, 还需要选定版本或连续性等额外结构; 积分恒等式本身不能唯一规定每个点的条件值。

考虑已经明确给定的教学模型

$$X = U_X, \quad T = f_T(X, U_T), \quad Y = 2X + 3T + U_Y. \quad (12.13)$$

它直接提供自然映射及替换处理规则后的映射。某人的事实为 $X = 2, T = 0, Y = 5$, 于是

$$U_Y = 5 - 2 \times 2 - 3 \times 0 = 1.$$

保持该人的 X, U_Y 不变, 把处理设为 1, 得到

$$Y_{T \leftarrow 1} = 2 \times 2 + 3 \times 1 + 1 = 8.$$

差值 3 来自给定结果规则中的处理作用。事实不必确定全部背景, 例如可能仍不知道 U_T ; 只要未确定部分不影响本次行动后的结果, 仍能得到这个点值。若结果规则不确定, 或未确定的背景继续进入结果, 则应给出条件分布或范围。

示例 12.11 两点背景后验的反事实推前 令背景类型 $U \in \{u_L, u_H\}$ 先验概率各为 $1/2$ 。事实中观察到二元信号 $S = 1$ ，且模型规定

$$\mathbb{P}(S = 1 | U = u_H) = \frac{3}{4}, \quad \mathbb{P}(S = 1 | U = u_L) = \frac{1}{4}.$$

因而 $\mathbb{P}(S = 1) = \frac{1}{2}(\frac{3}{4} + \frac{1}{4}) = \frac{1}{2}$ ，Bayes 公式给出

$$\mathbb{P}(U = u_H | S = 1) = \frac{3}{4}, \quad \mathbb{P}(U = u_L | S = 1) = \frac{1}{4}.$$

若行动 a 下的结果在两类背景中分别为 $F_{M,Y}^a(u_L) = 2, F_{M,Y}^a(u_H) = 6$ ，则

$$\mathcal{L}(Y_a | S = 1) = \frac{1}{4}\delta_2 + \frac{3}{4}\delta_6, \quad \mathbb{E}[Y_a | S = 1] = \frac{1}{4}2 + \frac{3}{4}6 = 5.$$

忽略事实而按先验重新抽取背景，得到总体干预分布 $\frac{1}{2}\delta_2 + \frac{1}{2}\delta_6$ ，均值为 4。两个答案使用同一行动映射，只是反事实计算保留了事实提供的背景信息。

若要把例子写成完整生成模型，可以用一个额外的独立随机量生成信号 S ，并让行动结果只依赖类型 U 。把测量随机量积分掉，就得到上面的两点后验分布。记录无法确定一个人属于哪一类时，保留两类的概率即可，无须强行选定一种类型。

还有一种更深的歧义：即使知道两种行动各自的总体分布，也未必知道同一个人的两个结果怎样配对。为单独考察这种配对歧义，下面另构造两套模型，令两种干预结果的分布都为 Bernoulli(1/2)。模型甲令一半单位满足 $(Y(0), Y(1)) = (0, 0)$ ，另一半满足 $(1, 1)$ ；模型乙令两类单位分别满足 $(0, 1)$ 和 $(1, 0)$ 。甲的个体效应恒为零，乙的个体效应等概率取 $1, -1$ ，而两模型的 ATE 都为零。

图 12.1 给出了对应的联合概率表。用定义 11.19 的语言，两者是相同边缘的不同耦合。已知 $Y(0) = 0$ 时，甲给 $Y(1) = 0$ ，乙给 $Y(1) = 1$ 。在独立随机分配处理的事实世界里，观察到 $T = 0, Y = 0$ 就能形成这项对照：两个模型仍给出不同反事实。

随机试验可以分别确定两种处理下的结果分布，却仍无法区分这两套个体配对。要回答“已知这个人未处理时结果为零，处理后会怎样”，还需要约束同一人的两个结果怎样共同生成，或使用具有适当稳定性、时间和前次处理残留效应假设的重复干预资料。否则应保留所有与资料相容的答案。模型明确给定时可以用式 (12.12) 计算，数据是否足以确定这套模型则是第 12.4 节的另一个问题。




图 12.1 相同干预边缘的两种跨世界配对。行对应 $Y(0)$ ，列对应 $Y(1)$ ，格内数字为联合概率；每张表的行和、列和均为 $1/2$ 。甲的个体效应恒为零，乙的个体效应等概率取 $1, -1$ ，两者 ATE 均为零。这是相容机制的教学构造，不是随机试验直接观察到的潜在结果联合表。

12.3.2 目标约束下的行动补救

反事实计算还可以反过来服务于行动选择：怎样以尽量低的代价，让同一个人的决策达到目标？先区分两种看似相近的操作。对预测器 $\hat{y} = f(x, t)$ ，输入替换给出

$$f(x, 1) - f(x, 0).$$

这只是已训练函数对字段变化的响应。若现实培训提高技能、同时占用工作时间，那么只改“是否培训”一列而锁住技能和时间，通常不是任何可实施的行动结果。这里用 x 表示已知的事实信息，例如既有技能、可用时间和当前成绩；这些信息决定允许采取哪些行动，以及各项行动的成本。目标还应明确，例如通过培训让成绩达到资格要求，从而获得有利决策。

定义 12.12 因果行动补救 给定事实证据、可实施行动集合 $\mathcal{A}(x)$ 、响应模型、行动成本 $c(a; x)$ 与目标决策集合 G ，行动补救 (algorithmic recourse) 寻找能够使行动后的决策落入 G 的可行行动。因果行动补救用同一背景下的干预状态 $V_a = F_M^a(\mathbf{u})$ 评价成功条件，并按机制重算所有受行动影响的状态。

令 d 为最终决策规则。若事实唯一确定背景 $\mathbf{u}$ ，优化形式为

$$\min_{a \in \mathcal{A}(x)} c(a; x) \quad \text{使得} \quad d(F_M^a(\mathbf{u})) \in G. \quad (12.14)$$

可行集合规定实际允许做什么，成本规定如何比较行动，成功约束规定要得到何种决策。这些要求可以写成第 4 章的约束优化问题。单独最小化输

入距离，却不能代替可行行动、行动成本和成功条件这三项要求。低输入距离不等于低行动成本；不可改变属性也不应成为行动建议。若可行集合为空，应报告无法在当前约束下补救，而不是输出一个不可执行的最近点。

多数实际记录无法唯一确定背景，只能给出背景的条件分布。给定可容许失败概率 $\alpha \in [0, 1]$ ，可以采用概率型约束

$$\mathbb{P}(d(F_M^a(\mathbf{U})) \in G \mid \mathbf{E} = \mathbf{e}) \geq 1 - \alpha. \quad (12.15)$$

若背景空间带有指定拓扑，可选所用条件分布版本的支持

$$\mathcal{S}_{\mathbf{e}} = \text{supp } P_{\mathbf{U}|\mathbf{E}=\mathbf{e}}.$$

要求

$$d(F_M^a(\mathbf{u})) \in G, \quad \mathbf{u} \in \mathcal{S}_{\mathbf{e}}, \quad (12.16)$$

得到支持上的最坏情形保证。一般可测空间没有默认的拓扑支持，此时应明确给出候选背景集合，而不是含糊使用“所有可能背景”。要求支持中每个点都成功，通常强于成功概率为 1：前者还要检查那些单点概率为零的背景，后者允许在零概率集合上失败。

两点后验例子可以直接比较这些条件。若目标是 $Y_a \geq 5$ ，行动 a 的后验成功概率为 $3/4$ ，因此在 $\alpha = 1/4$ 时满足概率约束；但低类型背景的结果为 2，不能满足支持上的最坏情形保证。只挑高类型作为“代表背景”会漏掉这项风险。

补救也有时间和多人联动的边界。许多人同时接受建议可能改变价格、名额或审核规则；决策系统更新后，原建议未必仍有效；资源竞争也可能使原先逐人可行的行动无法共同执行。因此当前模型中存在一个成功行动，不等于建议已经通过现实可行性、持久性或公平性验证。

12.3.3 目标属性干预下的公平补救

一个行动可以让某人获得有利决策，却未必满足公平要求。例如，在保持同一背景的模型比较中，同样的培训可能只在一种受保护属性取值下得到批准，在另一种取值下仍被拒绝。要讨论这种差别，必须先说明哪些属性影响应当被排除，以及替代属性在模型中如何改变其他状态。

令受保护属性为 A ，事实证据为 $(X = x, A = a)$ 。本小节的 X 泛指用于推断背景的其他事实，可能包含属性的后继变量；它不再具有 CATE 中“处理前且保持不变”的自动含义。事实中给定 $X = x$ ，并不要求替代属性世界的 X 仍等于 x 。

定义 12.13 反事实公平 在给定的响应模型与预测规则下，反事实公平 (counterfactual fairness) 要求：对每个允许的替代属性 a' 和每个可测预测值集合 B ，以下等式对事实证据分布几乎处处的 (x, a) 成立：

$$\begin{aligned} \mathbb{P}(\hat{Y}_{A \leftarrow a} \in B \mid X = x, A = a) \\ = \mathbb{P}(\hat{Y}_{A \leftarrow a'} \in B \mid X = x, A = a). \end{aligned} \quad (12.17)$$

两个属性世界均使用同一个事实背景条件分布，并重新计算由属性影响的状态及预测。

等式右侧仍以事实 $A = a$ 为条件，而不是改用另一群人的证据 $A = a'$ 。只在输入表中替换 A 并固定其全部后继变量，检验的是另一个对象。属性干预在这里是明确模型下的比较操作，也不表示应建议个人改变该属性。

把公平条件加入补救时，为避免与属性值混淆，记补救行动为 b 。要求模型已经规定联合行动映射 $F_M^{b, A \leftarrow a'}$ ：对每个属性世界，保留同一个可比较的行动 b ，不对该世界偷偷重新选择更有利的行动。行动与属性替换须互相兼容，且所比较世界中行动的可实施含义应明确。定义

$$\Pi_b^{a'}(B; x, a) = \mathbb{P}(d(F_M^{b, A \leftarrow a'}(U)) \in B \mid X = x, A = a).$$

一种公平约束补救问题是

$$\begin{aligned} \min_{b \in \mathcal{A}(x, a)} c(b; x, a) \\ \text{使得 } \Pi_b^a(G; x, a) \geq 1 - \alpha, \\ \Pi_b^{a'}(\cdot; x, a) = \Pi_b^a(\cdot; x, a) \text{ 对每个允许的 } a'. \end{aligned} \quad (12.18)$$

第一项约束要求行动有足够高的成功概率，第二项约束要求：根据同一份事实推断背景并施加同一行动时，替换受保护属性不能改变决策的条件分布。也可以另选近似公平或成本公平目标，但那会改变问题，不能把它们当作上述等式的自动结果。

示例 12.14 成功行动未必满足公平约束 设 $A \in \{0, 1\}$ ，自然培训量为 $B = 0$ ，资格分数与二元决策规则为

$$K = U + A + B, \quad d = \mathbb{I}\{K - 2A \geq 2\}.$$

可行行动是把培训量设为 $b \in [0, 3]$, 成本为 $c(b) = b$, 目标为 $d = 1$ 。已知事实 $A = 0, B = 0, K = 1$, 于是 $U = 1$ 。在两个属性世界中施加同一行动, 必须重算 K , 得到

$$K_{b, A \leftarrow a'} = 1 + a' + b, \quad d_{b, A \leftarrow a'} = \mathbb{I}\{1 + b - a' \geq 2\}.$$

只要求事实属性下成功时, 最小行动为 $b = 1$ 。但此时 $a' = 0$ 给决策 1, $a' = 1$ 给决策 0, 并不公平。若同时要求两个属性世界的二元决策相同且成功, 则必须 $b \geq 2$, 故最优行动为 $b = 2$ 。不行动时两个世界都失败, 虽然决策相同, 却不满足补救目标。

此例检验的是二元决策, 不是内部实值分数 $K - 2A$; 后者在两个属性世界中始终相差 1, 任何培训量都不能让分数分布相同。公平对象、允许行动及预算都会影响可行性。对一个已知个体成立的约束, 也不自动保证面向所有人的推荐规则公平; 后者还需规定推荐怎样依赖事实, 并对其目标人群几乎处处检验。

这些等式均以给定模型为条件。第 12.3.1 节的跨世界配对已经说明, 相同干预边缘也可能给出不同条件反事实; 由观测拟合出一套生成规则, 不等于公平或补救结论已被唯一识别。若多个模型都能解释证据, 应分别计算它们的结论, 再报告可能的范围。至于哪些属性影响或因果路径不应进入决策, 则需要另行说明公平判断的依据。第二卷“基础、理论和可信性”的“公平性”章与第二卷“基础、理论和可信性”的“可解释性”章继续讨论公平要求、解释和补救的应用及现实验证边界。

12.4 因果响应的推断

前面把模型作为输入。现在模型未知, 手中只有观察或试验资料, 并有一组愿意接受的机制假设。问题因而变为: 这些资料与假设是否足以确定所选响应目标? 定义 10.93 所述的识别思想在这里仍然适用, 只是模型索引从一般统计参数变成了完整生成机制。

记 P_{obs}^M 为模型 M 在已说明的数据收集方式下给出的可观测分布, $\tau(M)$ 为目标。在允许模型类中, 若

$$P_{\text{obs}}^{M_1} = P_{\text{obs}}^{M_2} \implies \tau(M_1) = \tau(M_2),$$

就称该目标可识别 (identifiable)。可观测分布可以包括已完成的试验资料, 不必只包括自然观察。目标可识别也不要求模型每个组成部分都唯一确定。

这是总体层面的唯一性, 须与有限样本估计、数值计算区分。估计用样本逼近总体量, 计算求出给定表达式或优化问题的答案。一个算法可以精

确拟合全部观测条件分布，却仍无法区分本章开头的两套机制；反过来，目标已有识别式，也不表示样本够多或数值算法已经稳定。

12.4.1 响应目标的点识别

要从事实数据恢复响应，关键是找到哪些可见单位可以代表目标行动下的结果。随机分配直接建立可比性；观察研究则通常需要在足够的处理前信息下作比较。以下先把条件写成潜在结果关系，不要求事先得到一张完全识别的因果图。

12.4.1.1 随机分配下的边缘识别

若处理由独立随机装置分配，且两种处理都有正概率，则 $(Y(0), Y(1)) \perp T$ 。结合一致性，对任意可测集合 B 及 $t \in \{0, 1\}$ ，有

$$\mathbb{P}(Y(t) \in B) = \mathbb{P}(Y(t) \in B \mid T = t) = \mathbb{P}(Y \in B \mid T = t). \quad (12.19)$$

第一个等号来自随机分配，第二个来自实际处理与潜在结果的一致性；正概率保证右侧有相应处理组。结果可积时，同一论证给出

$$\mathbb{E}[Y(t)] = \mathbb{E}[Y(t) \mid T = t] = \mathbb{E}[Y \mid T = t],$$

所以两组均值差识别 ATE。

式 (12.19) 识别的是每个潜在结果的完整边缘，不是 $(Y(0), Y(1))$ 的联合分布。第 12.3.1 节的两套配对因此仍与随机试验相容。若实际分析存在失访、不依从、处理溢出或随机化后的样本筛选，应按真实目标重新检查独立性和一致性。例如随机分配的邀请不等于实际参加培训，按参加者重新分组不会自动继承原随机化。

12.4.1.2 条件交换下的调整识别

观察研究不能随意重排处理，但可以尝试用处理前 X 解释分配差异。这里的 X 须在所比较处理下保持同一取值和含义，否则两组不再按共同背景分层。

定义 12.15 条件交换性 对二元处理，条件交换性 (conditional exchangeability) 要求

$$(Y(0), Y(1)) \perp T \mid X. \quad (12.20)$$

直观上，固定 X 后，进入处理组不再额外透露潜在结果的信息；例如 X 已经包含需要控制的共同背景。这不同于概率论中样本序列在重排下分布不变的可交换性。它涉及不能同时观察的结果，不能凭处理预测准确率或

结果拟合误差验证。对单个边缘目标，只需相应的 $Y(t) \perp T \mid X$ ；上式是同时表达两种处理可比性的较强条件。

定义 12.16 二元处理的支持重叠 记倾向概率为 $e(x) = \mathbb{P}(T = 1 \mid X = x)$ 。对需要比较两种处理的目标总体，支持重叠 (overlap)，也称正值性 (positivity)，要求

$$0 < e(x) < 1, \quad P_X \text{ 几乎处处.} \quad (12.21)$$

交换性解释参照人群为何可比，支持重叠保证参照确实存在。若某类人必然接受处理，即使愿意假设其未处理潜在结果与分配条件独立，也没有该类人的未处理记录可用。

正值性随目标而定。识别 $\mathbb{E}[Y(1)]$ 只需目标总体几乎处处有 $e(x) > 0$ ，识别 $\mathbb{E}[Y(0)]$ 只需 $e(x) < 1$ ，ATE 才同时需要两侧条件。对目标策略，只有它会使用的背景与行动组合需要被观测支持覆盖；目标总体以外的背景和策略从不采取的行动不在要求内。若另换目标总体，其背景支持和跨总体条件响应的可比性也要重新检查。

假设一致性、条件交换性、所需支持及潜在结果可积性成立。全期望先给出

$$\mathbb{E}[Y(t)] = \mathbb{E}_X[\mathbb{E}[Y(t) \mid X]].$$

交换性允许在内层加入处理条件：

$$\mathbb{E}[Y(t) \mid X] = \mathbb{E}[Y(t) \mid T = t, X].$$

正值性保证右侧在目标所需的背景上由相应处理组定义，一致性再将 $Y(t)$ 换成观察结果，得到调整公式

$$\mathbb{E}[Y(t)] = \mathbb{E}_X[\mathbb{E}[Y \mid T = t, X]]. \quad (12.22)$$

令 $\mu_t(x) = \mathbb{E}[Y \mid T = t, X = x]$ ，两式相减便有

$$\tau = \mathbb{E}_X[\mu_1(X) - \mu_0(X)]. \quad (12.23)$$

若把结果换成事件指示量，同样可以识别各干预边缘的事件概率。

同一目标还有逆概率表示。对处理组，由条件期望

$$\begin{aligned} \mathbb{E}\left[\frac{TY}{e(X)} \mid X\right] &= \frac{\mathbb{P}(T = 1 \mid X)}{e(X)} \mathbb{E}[Y \mid T = 1, X] \\ &= \mu_1(X). \end{aligned}$$

未处理组同理满足

$$\mathbb{E}\left[\frac{(1-T)Y}{1-e(X)}\middle|X\right] = \mu_0(X).$$

可积性使这些期望存在，再取总体期望得到

$$\tau = \mathbb{E}\left[\frac{TY}{e(X)} - \frac{(1-T)Y}{1-e(X)}\right]. \quad (12.24)$$

条件均值法先比较相同背景下的两组结果，再按目标人群的构成平均。加权法则提高那些较少进入某处理组的背景类型的权重，使加权后的人群构成与目标相符。两者用不同公式表达同一识别关系，依赖的因果假设相同。

下面仍用培训问题，把分配差异具体算出来。设 $X \in \{0, 1\}$ 表示培训前的基础水平， $X = 1$ 表示基础较好。把成绩缩放到 $[0, 1]$ ，并设 $\mathbb{P}(X = 1) = 1/2$ ，且

$$e(1) = 0.8, \quad e(0) = 0.2.$$

给定 X 后假设交换性成立，潜在结果均值取教学数值

	$X = 0$	$X = 1$
$\mathbb{E}[Y(0) X]$	0.1	0.5
$\mathbb{E}[Y(1) X]$	0.3	0.7

两层效应都为 0.2，所以

$$\tau = \frac{1}{2}(0.3 - 0.1) + \frac{1}{2}(0.7 - 0.5) = 0.2.$$

自然处理中 $\mathbb{P}(T = 1) = \frac{1}{2}(0.8 + 0.2) = 1/2$ ，Bayes 公式给出

$$\mathbb{P}(X = 1 | T = 1) = 0.8, \quad \mathbb{P}(X = 1 | T = 0) = 0.2.$$

于是观察到的两组均值为

$$\mathbb{E}[Y | T = 1] = 0.8 \times 0.7 + 0.2 \times 0.3 = 0.62,$$

$$\mathbb{E}[Y | T = 0] = 0.2 \times 0.5 + 0.8 \times 0.1 = 0.18.$$

观测差为 0.44，大于调整后的 0.20，因为基础较好的人更常参加培训，培训组的成绩优势同时包含了原有基础和培训作用。按共同的 P_X 重新平均，才排除两组基础构成不同带来的差异，恢复所定义的总体效应。

这也说明三项假设各管什么。一致性连接观测和潜在结果，交换性允许同层比较，重叠让每层都有所需的处理记录。若未记录的学习动机同时影响参加意愿和成绩，交换性就可能不成立；若 $e(1) = 1$ ，基础较好的人全都参加培训，资料便完全缺少这类人未参加时的结果。相反， $e(1)$ 很接近但未等于 1 时，点识别仍成立，只是有限样本中权重可能很大。选择哪些协变量足以支持调整，需要领域知识或能支持这些假设的生成结构；

第 12.5.3.3 节在建立图语义后给出一种充分准则，这里并未假定该准则已经被验证。

12.4.2 响应目标的部分识别

若不愿接受完整交换性，或目标行动落入无数据的区域，仍可询问现有信息排除了哪些答案。这就是部分识别（partial identification）：保留所有相容机制给出的目标值，不用一个未经支持的点掩盖机制歧义。

定义 12.17 识别集合 设 $\mathcal{M}(P_{\text{obs}})$ 是与可观测分布及已声明假设相容的模型集合，目标为 $\tau(M)$ 。其识别集合（identified set）是

$$\mathcal{I}(P_{\text{obs}}) = \{\tau(M) : M \in \mathcal{M}(P_{\text{obs}})\}. \quad (12.25)$$

相容类为空意味着假设与观测不相容，并不是“目标取空值”。以下讨论相容类非空的情形。一般识别集合可能由分离的点或区间组成；下确界和上确界只给区间包络，不能保证包络内每个值可达。只有另外证明中间值可达，才能把整个区间称为识别集合。

12.4.2.1 结果约束下的效应界

先只保留一致性及结果范围 $0 \leq Y(t) \leq 1$ ，不假设交换性。二元处理下，

$$\begin{aligned} \mathbb{E}[Y(1)] &= \mathbb{E}[TY(1)] + \mathbb{E}[(1-T)Y(1)] \\ &= \mathbb{E}[TY] + \mathbb{E}[(1-T)Y(1)]. \end{aligned}$$

第一项已经观察到；第二项是未处理者接受处理后的结果。由范围约束，

$$0 \leq \mathbb{E}[(1-T)Y(1)] \leq \mathbb{P}(T=0),$$

所以

$$\mathbb{E}[TY] \leq \mathbb{E}[Y(1)] \leq \mathbb{E}[TY] + \mathbb{P}(T=0). \quad (12.26)$$

对另一处理，同样将 $\mathbb{E}[Y(0)] = \mathbb{E}[(1-T)Y] + \mathbb{E}[TY(0)]$ 分成可见与缺失部分，得到

$$\mathbb{E}[(1-T)Y] \leq \mathbb{E}[Y(0)] \leq \mathbb{E}[(1-T)Y] + \mathbb{P}(T=1). \quad (12.27)$$

用 $\mathbb{E}[Y(1)]$ 的下界减去 $\mathbb{E}[Y(0)]$ 的上界，得到效应下界；交换上下界的组合，得到效应上界：

$$\begin{aligned} \mathbb{E}[TY] - \mathbb{E}[(1-T)Y] - \mathbb{P}(T=1) &\leq \tau \\ &\leq \mathbb{E}[TY] + \mathbb{P}(T=0) - \mathbb{E}[(1-T)Y]. \end{aligned} \quad (12.28)$$

界宽并不一定表示推导粗糙；它可能正是资料缺失造成的。

定义 12.18 相容机制类中的锐界 对非空相容类 $\mathcal{M}(P_{\text{obs}})$ 与实值目标，若下界与上界分别等于 $\inf_{M \in \mathcal{M}} \tau(M)$ 及 $\sup_{M \in \mathcal{M}} \tau(M)$ ，就称为该机制类中的锐界 (sharp bounds)。端点可以达到，也可以仅由相容机制序列任意逼近。

式 (12.28) 在当前不受其他限制的机制类中是锐的。要达到下界，保持所有实际记录不变，令未处理者缺失的 $Y(1) = 0$ ，已处理者缺失的 $Y(0) = 1$ 。要达到上界，则把这两类缺失结果分别设为 1 和 0。两种构造都满足一致性和结果范围，也不改变 P_{obs} 。

中间值也可构造。独立抽取一个概率为 λ 的二元背景标记，按该标记选择上端构造，否则选择下端构造；事实记录不变，只切换缺失结果的赋值。混合机制的效应为 $\lambda\tau_{\text{up}} + (1 - \lambda)\tau_{\text{low}}$ 。让 λ 遍历 $[0, 1]$ ，便得到整个区间。因此区间中的每个值都有相容机制实现；在当前假设下，无法仅靠改进代数推导缩窄这个区间。若再要求个体单调性、平滑函数或特定跨世界结构，上述赋值可能不再允许，锐界必须新的模型类中重新计算。

12.4.2.2 支持缺口下的效应与策略界

现在假设条件交换性可信，但双侧重叠只在协变量区域 $\mathcal{O}$ 成立。用 $\mathcal{N}$ 表示目标总体中缺少某种处理的区域，两者不交且覆盖目标总体。结果仍在 $[0, 1]$ 时，条件效应 $\tau(x) \in [-1, 1]$ ，故

$$\tau = \mathbb{E}[\tau(X)\mathbb{I}\{X \in \mathcal{O}\}] + \mathbb{E}[\tau(X)\mathbb{I}\{X \in \mathcal{N}\}].$$

第一项由调整式识别，第二项只能先按范围控制，得到

$$\begin{aligned} \mathbb{E}[\tau(X)\mathbb{I}\{X \in \mathcal{O}\}] - \mathbb{P}(X \in \mathcal{N}) &\leq \tau \\ &\leq \mathbb{E}[\tau(X)\mathbb{I}\{X \in \mathcal{O}\}] + \mathbb{P}(X \in \mathcal{N}). \end{aligned} \quad (12.29)$$

这是一组有效界，未声称总是锐界；缺口区域中若仍观察到一种处理的结果，利用这一侧均值还可能收紧。限制目标人群到 $\mathcal{O}$ 可以点识别重叠人群效应，但已经改变了目标总体。假设缺口内效应与邻近区域平滑、同号或落在更小范围，也能收紧答案，却都是额外外推条件，不能由已覆盖部分的拟合优度证明。

单步策略评价需要的支持可以更少。沿用式 (12.10) 的有限动作集合及目标策略 π ，记日志动作概率为 $e_a(x) = \mathbb{P}(T = a \mid X = x)$ 。假设对所有动作， $L \leq Y(a) \leq H$ ，且一致性和给定 X 的交换性成立。若目标覆盖条件为

$$\pi(a \mid x) > 0 \implies e_a(x) > 0$$

并在目标总体中几乎处处成立, 则

$$\begin{aligned}\mathbb{E}\left[\frac{\pi(T|X)}{e_T(X)}Y|X\right] &= \sum_{\substack{a \in \mathcal{A} \\ e_a(X) > 0}} e_a(X) \frac{\pi(a|X)}{e_a(X)} \mathbb{E}[Y|T=a, X] \\ &= \sum_{a \in \mathcal{A}} \pi(a|X) \mathbb{E}[Y(a)|X].\end{aligned}$$

对 X 取期望, 得到

$$V(\pi) = \mathbb{E}\left[\frac{\pi(T|X)}{e_T(X)}Y\right]. \quad (12.30)$$

这是第 10.3.3 节换测度的一个因果用途: 改变动作分配, 保留给定背景与动作的结果机制。权重只在日志实际可能选择的动作上求值, 覆盖条件使其余动作的目标概率为零, 无须引入 0/0 约定。

如果目标策略会选择某些日志收集规则下概率为零的背景-行动组合, 就它的价值分成两部分: 缺口部分所占的概率 r , 以及已有记录能确定的价值贡献 K :

$$\begin{aligned}r &= \mathbb{E}_X \left[\sum_{a: e_a(X)=0} \pi(a|X) \right], \\ K &= \mathbb{E}_X \left[\sum_{a: e_a(X)>0} \pi(a|X) \mathbb{E}[Y|T=a, X] \right].\end{aligned}$$

缺口部分的贡献在 $[Lr, Hr]$ 内, 因而

$$K + Lr \leq V(\pi) \leq K + Hr. \quad (12.31)$$

两个策略的价值范围若完全分离, 就能确定排序; 若重叠, 单独看边际范围未必能判断。它们使用同一组未知潜在结果, 不能把各自端点当作独立可选。例如两策略完全相同时, 无论各自的价值范围多宽, 价值差都严格为零。一般应对

$$V(\pi_1) - V(\pi_2) = \mathbb{E}_X \sum_a (\pi_1(a|X) - \pi_2(a|X)) \mathbb{E}[Y(a)|X]$$

直接构造联合识别集合或上下界。拟合器对缺口给出的单一外推, 不是额外的排序证据。

图 12.2 把混杂与覆盖分别数值化。左图回顾前面的基础水平分层例子; 右图另设结果范围为 $[0, 1]$, 已覆盖部分条件平均收益为 0.6, 故 $K = 0.6(1 - r)$ 。在 $r = 0.2$ 时, 价值范围为 $[0.48, 0.68]$ 。宽度 0.2 来自缺口中的未知结果机制, 不会因增加同一覆盖区域内的样本而消失。




图 12.2 两个独立的教学构造。左图比较基础水平分层例子的观测均值差 0.44 与调整效应 0.20。右图按式 (12.31) 绘制 $[0.6(1-r), 0.6(1-r)+r]$ 。阴影为总体识别范围，不是抽样置信带；两个面板不表示同一数据集。

这里每个策略只选择一次行动。第 15.4.2 节建立序贯策略后，必须逐时检查历史覆盖、时间变化的混杂及轨迹结果定义，不能把单步权重直接套到整条轨迹。

12.4.2.3 未观测混杂下的敏感性范围

即使每类已记录背景都有两种处理，也可能仍有影响分配和结果的因素没有被记录。例如，既有成绩相同的两个人，学习动机较强的人可能更愿意参加培训，也更容易提高成绩；如果学习动机没有记录，按既有成绩分组仍无法排除这种差异。敏感性分析为未记录因素造成的偏差规定允许范围，再检查效应结论随该范围怎样变化。

先用一个简单线性模型说明偏差从哪里产生。设变量中心化，

$$T = \alpha U + \varepsilon_T, \quad Y = \beta T + \gamma U + \varepsilon_Y,$$

其中 $U, \varepsilon_T, \varepsilon_Y$ 两两独立、方差有限，且 $\text{Var}(T) > 0$ 。理想设定 $T = t$ 时，固定背景的结果对 t 的导数为 β 。但只将 Y 对自然处理 T 作总体线性回归，得到

$$\begin{aligned} \beta_{\text{obs}} &= \frac{\text{Cov}(T, Y)}{\text{Var}(T)} \\ &= \beta + \gamma \frac{\alpha \text{Var}(U)}{\text{Var}(T)}. \end{aligned} \quad (12.32)$$

这里用到了 $\text{Cov}(T, Y) = \beta \text{Var}(T) + \gamma \text{Cov}(T, U)$ ，以及 $\text{Cov}(T, U) = \alpha \text{Var}(U)$ 。共同背景同时进入处理与结果，产生了第二项。若仅支持该偏差绝对值不超过 Λ ，则 $\beta \in [\beta_{\text{obs}} - \Lambda, \beta_{\text{obs}} + \Lambda]$ 。观测可以估计 β_{obs} ，

却不能在有限信息时把 α, γ, β 各自分开；改变函数形式也会改变敏感性参数的含义。

异质或非线性响应不一定有一个统一斜率修正量。仍记 $\mu_t(x) = \mathbb{E}[Y | T = t, X = x]$ 和 $e(x) = \mathbb{P}(T = 1 | X = x)$ 。在 $0 < e(x) < 1$ 且相关条件期望有限时，定义选择偏差函数

$$b_1(x) = \mathbb{E}[Y(1) | T = 1, X = x] - \mathbb{E}[Y(1) | T = 0, X = x],$$

$$b_0(x) = \mathbb{E}[Y(0) | T = 1, X = x] - \mathbb{E}[Y(0) | T = 0, X = x].$$

条件交换性蕴含 $b_1 = b_0 = 0$ ，但反过来只得到条件均值交换性，不能推出完整潜在结果分布相同。比如两组都均值为零，一组恒等于零，另一组等概率取 1, -1，均值相同仍保留分布差异。

一致性给出 $\mathbb{E}[Y(1) | T = 1, X = x] = \mu_1(x)$ ，再由全期望

$$\begin{aligned} \mathbb{E}[Y(1) | X = x] &= e(x)\mu_1(x) + (1 - e(x))(\mu_1(x) - b_1(x)) \\ &= \mu_1(x) - (1 - e(x))b_1(x). \end{aligned}$$

另一侧有

$$\begin{aligned} \mathbb{E}[Y(0) | X = x] &= (1 - e(x))\mu_0(x) + e(x)(\mu_0(x) + b_0(x)) \\ &= \mu_0(x) + e(x)b_0(x). \end{aligned}$$

相减得到

$$\tau(x) = \mu_1(x) - \mu_0(x) - (1 - e(x))b_1(x) - e(x)b_0(x). \quad (12.33)$$

若领域知识仅支持 $|b_1(x)| \leq \Gamma_1(x)$ 及 $|b_0(x)| \leq \Gamma_0(x)$ ，三角不等式给出

$$\begin{aligned} \mu_1(x) - \mu_0(x) - \Delta(x) &\leq \tau(x) \\ &\leq \mu_1(x) - \mu_0(x) + \Delta(x), \end{aligned} \quad (12.34)$$

其中 $\Delta(x) = (1 - e(x))\Gamma_1(x) + e(x)\Gamma_0(x)$ 。重叠在目标总体几乎处处成立、潜在结果及相应控制量可积时，再对 X 平均便得到 ATE 范围。该范围是当前偏差约束的有效包络；若还有限定结果范围或其他联合约束，不能未经可达性检查就宣称它为锐界。

Γ_t 是关于未观测差异的假设，不是样本自动生成的误差条。报告应展示在多大强度下结论变号或越过决策阈值，而不只给一个恰好保留原结论的值。其他有根据的假设也能缩小相容类。例如个体单调性 (monotonicity)

$$Y(1) \geq Y(0) \quad \text{几乎必然}$$

排除所有受损个体，故 ATE 至少为零，可以将有效下界提高到零。它比“平均有益”更强。若已知个体效应位于 $[-\rho, \rho]$ ，支持缺口中的 $[-1, 1]$ 可换成更窄范围；平滑外推也必须作为新增机制限制声明。

跨环境资料可以提供另一种约束。若源环境有随机试验，目标环境给出协变量分布，并假设条件效应在两环境相同，且目标协变量分布对源环境分布绝对连续，即源环境的零概率背景集在目标环境中也为零概率，则

$$\tau_{\text{target}} = \int \tau_{\text{source}}(x) P_{X, \text{target}}(dx).$$

这是条件效应稳定和覆盖共同给出的运输关系；在离散情形，覆盖要求目标中出现的背景在源环境也有正概率。连续情形仅有拓扑支持包含还不够，应使用上述绝对连续条件。它们都不是看到稳定预测关联就自动成立。共同隐藏原因、选择过程或多个机制同步变化都可能产生稳定关联。

相容类也可用于第 12.3 节的反事实、补救与公平目标。跨世界配对不同的模型可能同样解释试验边缘，却改变行动成功概率或公平判断。此时应检查不同相容模型怎样改变结论，并报告相应范围。只报告某一选定模型内的模拟误差，会漏掉模型选择本身的不确定性。

12.4.3 有限样本下的响应估计

即使识别式成立，条件响应、处理概率与总体权重通常仍需从样本估计。比如调整法用 $\hat{\mu}_t$ 代替 μ_t ，再在目标背景样本上平均：

$$\hat{\tau} = \frac{1}{n} \sum_{i=1}^n (\hat{\mu}_1(X_i) - \hat{\mu}_0(X_i)).$$

这只是识别式的一种代入估计，不自动具有无偏性或某种收敛速度。拟合误差、目标样本的抽样误差以及重复使用同一数据引入的依赖，仍须按第 10.5 节的估计与数据复用规则分析。采用样本拆分或交叉拟合时，应明确哪些样本拟合、哪些样本评价，以及相应误差条件。

逆概率法还要估计倾向概率。很小但非零的真实概率允许总体识别，却可能使估计方差很大；截断权重可改变偏差与方差，但不能被解释为凭空补足支持。更灵活的拟合器或交叉拟合同样不能修复交换性错误。

部分识别时，估计对象可以是识别集合的端点或其外包络。识别集合在总体分布已知时仍可能不是单点，表达机制歧义；置信区间来自有限样本，表达总体目标、识别集合或端点的估计误差。对端点构造置信范围，还需按所用统计方法处理两个端点共同的覆盖要求，不能把端点估计直接当作已知真界。

实际报告应分别列出相容机制留下的范围、抽样造成的不确定性，以及积分或优化中的数值误差。增加样本主要改善第二项，改善算法主要影响

第三项；改变设计、扩大目标行动覆盖或加入可辩护的机制限制，才可能缩小第一项。尤其在效应符号或行动阈值附近，应同时报告对支持处理、敏感性参数及目标总体选择的依赖。

12.5 因果生成结构的表示

前面假定模型能直接给出行动后的结果。现在追问它怎样算出这个结果：培训先改变技能，技能再影响成绩，怎样把这些局部关系组合成整体响应？为此既要写出每个变量的生成函数，也要给出背景的联合分布。方程说明怎样产生数值，图说明每个方程使用哪些输入；两者共同决定行动要替换什么，以及替换后哪些变量需要重算。

12.5.1 局部机制的结构方程表示

把模型内需要解释的变量称为内生变量，把当前模型不再解释的背景称为外生变量。“外生”是相对于模型边界而言，并不意味着这些量在现实中没有原因，也不自动意味着它们彼此独立。进入某个变量生成函数的其他内生变量称为它的父变量，表示该局部机制直接使用哪些输入。

定义 12.19 无环结构因果模型 本章的结构因果模型 (structural causal model, SCM) 由内生变量 $\mathbf{V} = (V_1, \dots, V_d)$ 的可测状态空间、外生背景 $\mathbf{U} = (U_1, \dots, U_d)$ 的联合分布及可测结构函数组成：

$$V_j = f_j(\text{pa}_j, U_j), \quad j = 1, \dots, d. \quad (12.35)$$

其中 pa_j 收集进入第 j 个函数的其他内生变量。无环 (acyclic) 要求存在节点次序 $j_1, \dots, j_d$ ，使每个函数的内生输入都来自次序中更早的节点。外生分量可以相关。

把每个内生变量画成节点，在 V_k 作为输入进入 f_j 时画箭头 $V_k \rightarrow V_j$ ，便得到有向无环图，简称 DAG。上述求值次序已足以理解无环性，不需要先学习图排序算法。SCM 的箭头具有生成语义；若箭头只用于表示联合分布的条件分解，就不能据此判断改变输入的后果²。

例如，培训 T 、技能 M 和成绩 Y 可以写成

$$T = f_T(U_T), \quad M = \alpha T + U_M, \quad Y = \beta T + \gamma M + U_Y.$$

这里的直接输入关系为 $T \rightarrow M$ 、 $T \rightarrow Y$ 、 $M \rightarrow Y$ 。若 U_T, U_M, U_Y 相关，处理选择还可能与技能或成绩背景相联系；仅画出这三条内生边不足以表示全部共同背景。要使用独立噪声 DAG 的概率规则，必须另行要求这些背景独立，或把相关性的共同来源显式放进模型。

² J. Pearl, *Causality: Models, Reasoning, and Inference*, Cambridge University Press, 2009, 2nd ed.

有限维模型可以把局部函数写成 f_{j,θ_j} ，并用 $\theta = (\theta_1, \dots, \theta_d)$ 汇集参数。上例的 α, β, γ 是局部作用参数；一般 SCM 则不必属于有限维函数族。指定关系但不知道函数，或拟合函数却没有确定它的因果语义，都仍留下结构上的未知。

12.5.2 局部机制的复合与响应生成

有了局部方程，定义 12.1 假定的自然映射就可以实际构造。按无环次序计算时，每一步只使用此前已经得到的值，因此既给出计算过程，也排除了同一背景下出现多个自然解的歧义。

定理 12.20 无环机制的唯一可测响应 对定义 12.19 中的模型，每个背景 $\mathbf{u}$ 唯一确定一组满足所有结构方程的内生取值。所得自然映射 $F_M : \mathcal{U} \rightarrow \mathcal{V}$ 可测。将任意指定的一组方程替换为常量方程后，所得映射 F_M^a 同样存在、唯一且可测。对单变量理想干预，响应 $(t, \mathbf{u}) \mapsto R_M(t, \mathbf{u})$ 联合可测。

证明. 取符合无环性的次序 $j_1, \dots, j_d$ 。第一个变量没有内生父变量，因而 $v_{j_1} = f_{j_1}(u_{j_1})$ 唯一确定，且是 $\mathbf{u}$ 的可测函数。假设前 $k-1$ 个变量已唯一确定为可测函数。第 k 个方程的父变量都在其中，将这些函数及 u_{j_k} 代入可测的 f_{j_k} ，便得到唯一且可测的 v_{j_k} 。归纳到 d ，得到满足全部方程的可测向量 $F_M(\mathbf{u})$ 。任何另一组解在第一个坐标都必须相同；逐坐标应用同一理由，便证明唯一性。

常量替换只删除输入，不增加逆向依赖，原次序仍可使用。被替换坐标直接取行动指定值，其余坐标按同样归纳求出，从而得到 F_M^a 。若把处理值 t 也作为输入，被替换坐标是乘积空间上的投影 $(t, \mathbf{u}) \mapsto t$ ，其余步骤仍是可测函数的复合，因此 $F_M^{a(t)}(\mathbf{u})$ 及其结果坐标 $R_M(t, \mathbf{u})$ 联合可测。 ■

自然分布是 $(F_M)_\# P_{\mathbf{U}}$ ，干预分布是 $(F_M^a)_\# P_{\mathbf{U}}$ 。两个推前共用同一个背景分布，只改变生成映射。若理想干预值恰好等于该背景下的自然处理值，那么自然解也满足替换后的全部方程；由唯一性，两组解相同。这也证明了这种构造中的一致性，而不只是另行假定 $Y = Y(T)$ 。

若结果方程为 $Y = f_Y(T, X, U_Y)$ ，且 X 不受处理干预影响，则

$$Y(t) = f_Y(t, X, U_Y). \quad (12.36)$$

因此 $\mathcal{L}(Y(t)) = \mathcal{L}(Y \mid \text{do}(T = t))$ 。若结果还依赖处理会改变的技能 M ，则必须先重算 $M(t)$ ，不能仍代入事实技能。对上面的线性机制，

$$M(t) = \alpha t + U_M, \quad Y(t) = (\beta + \gamma\alpha)t + \gamma U_M + U_Y,$$

所以整体响应导数为 $\beta + \gamma\alpha$ ，不只是局部结果方程中固定 M 时的偏导数 β 。取 $\alpha = 2, \beta = 1, \gamma = 3$ ，增加一单位培训使成绩增加 7，其中直接贡献为 1，经技能传递的贡献为 6。对可微的非线性机制 $M = f_M(T, U_M)$ 、 $Y = f_Y(T, M, U_Y)$ ，链式法则给出

$$\frac{\partial R_M(t, \mathbf{u})}{\partial t} = \frac{\partial f_Y}{\partial t} + \frac{\partial f_Y}{\partial m} \frac{\partial f_M}{\partial t},$$

各偏导数均在该背景的干预取值处计算。这连接了第 12.2.3 节的整体局部变化与本节的局部方程；对它再作总体平均，仍须检查导数与积分交换条件。

在外生噪声相互独立时，还可以用局部概率核表达同一计算。记

$$K_j(B | \mathbf{v}_{\text{pa}_j}) = \mathbb{P}(f_j(\mathbf{v}_{\text{pa}_j}, U_j) \in B).$$

每个核都由机制及噪声分布指定，沿无环次序复合这些核便得到联合分布。独立性保证当前噪声不会被已经生成的变量额外筛选。若这些核具有质量函数或密度，则

$$p(\mathbf{v}) = \prod_{j=1}^d p(v_j | \text{pa}_j).$$

理想干预把处理核换成点质量，其余核保持原样，于是得到截断分解

$$p(\mathbf{v}_{-T} | \text{do}(T = t)) = \prod_{j: V_j \neq T} p(v_j | \text{pa}_j) \Big|_{T=t}. \quad (12.37)$$

这里 $\mathbf{v}_{-T}$ 表示删除处理坐标后的变量集合。公式来自机制替换，不是对任意概率分解删除一个因子都能得到因果分布。外生噪声相关时，上述独立核复合一般不成立；应回到完整背景的推前，或显式展开相关来源。

这里每个局部条件分布的具体取值都必须由结构机制指定。观测分布只按父变量分布几乎处处确定条件分布，并不指定每一个点的取值。干预若产生了未见过的父变量组合，机制可以给出答案，但资料未必能识别该答案。随意补一个支持外的条件密度，不会把模型外推变成数据结论。

对简单结构 $X \rightarrow T, X \rightarrow Y, T \rightarrow Y$ ，用独立的新随机量按 $q(t | x)$ 分配处理，并保持其余独立噪声机制不变，得到

$$p^q(x, t, y) = p(x)q(t | x)p(y | t, x). \quad (12.38)$$

这正是第 12.1.2 节随机干预构造的局部表达。确定性策略用点质量核表示，不必假装它有通常的 Lebesgue 密度。策略若同时改变参与人群、结果测量或其他机制，就不能只替换处理因子。更一般的机制替换也需要保证修改后的方程有明确解；添加依赖关系时，原无环次序可能不再适用。

循环方程说明这一边界并非形式问题。例如 $V_1 = V_2 + 1, V_2 = V_1$ 无解，而 $V_1 = V_2, V_2 = V_1$ 有无穷多组解。反馈系统可能需要动态演化、平衡选择或额外唯一性条件，不能直接套用本节递归证明。

12.5.3 变量关系的图表示与调整条件

完整求解 SCM 可以得到响应，但有时只需回答一个较窄的问题：哪些变量适合用来调整处理组之间的背景差异？图保留直接输入关系而暂时略去具体函数，因而能在一类机制上共同作出判断。下面先解释共同原因、中介和选择怎样影响两组比较，再检查全图是否还有未阻断的路径，最后说明哪些图条件能支持前面的调整公式。

12.5.3.1 局部因果关系与调整影响

结构 $T \leftarrow X \rightarrow Y$ 把 X 称为 T 与 Y 的共同原因 (common cause)。即使处理并不影响结果，不同 X 人群接受处理的比例不同，也会使 T, Y 在自然记录中相关。这是混杂产生的一种方式。第 12.4.1.2 节的基础水平分层算例正是通过在同一背景层比较，再用同一目标权重平均，消除了由两组构成不同造成的差异。

结构 $T \rightarrow M \rightarrow Y$ 中的 M 是中介变量 (mediator)：处理对结果的一部分影响经过它传递。若目标是总效应，固定 M 会阻断这部分变化；若研究同时设定 $T = t, M = m$ 的响应，则需明确这是不同的联合干预。在线性例子中，固定中介后的处理系数为 β ，让中介随处理变化的总系数为 $\beta + \gamma\alpha$ 。这并不建立一般路径效应的识别公式，只说明两种目标不同。

结构 $T \rightarrow C \leftarrow Y$ 中的 C 是碰撞点 (collider)，两条箭头在此相遇。不以 C 筛选时，这条路径本身不要求两端相关；一旦给定 C ，却可能引入关联。例如两个独立能力共同决定总分，入选要求总分超过阈值且两项能力可以补偿，那么入选者中一项能力较弱的人往往需要另一项更强。若入选规则改成两项能力分别超过各自阈值，这种负关联未必出现。关系的方向取决于选择机制，不能把选择后的相关解释为一种能力造成另一种能力。

图 12.3 中的双边框表示中间变量被加入条件集。共同原因和中介在该路径上都是非碰撞点，给定后会关闭路径；碰撞点的行为相反。这解释了为何“控制更多变量”不是普遍有效的做法，也预告了局部路径能否关闭与全图是否仍有其他路径是两件事。

12.5.3.2 全图路径分离与概率约束

较大图中，关闭一个局部片段仍可能留下另一条联系。设 $\mathcal{G} = (V, E)$ 是有向无环图， V 是节点集、 E 是有向边集。下面沿用定义 9.1 的图分离判据，在生成模型中解释它怎样约束随机变量的条件独立。路径仍指底层图中相




图 12.3 共同原因、中介与碰撞点的局部路径。双边框表示节点已加入条件集。共同原因和中介是非碰撞点，给定后关闭这条路径；给定碰撞点则打开原本关闭的路径。路径打开表示图不再保证相应独立性，并不指定相关的大小或正负。

邻且互不重复的节点序列，有向路径才要求沿箭头前进；祖先和后代均不包括节点自身。

定义 12.21 图分离与概率独立的记号 对两两不交的节点集 A, B, S ，其中 A, B 非空， $A \perp_g B \mid S$ 表示图中连接 A, B 的每条路径都被 S 阻断；活跃路径的碰撞与非碰撞规则沿用定义 9.1。若各节点承载随机变量， $X_A \perp X_B \mid X_S$ 则表示给定 X_S 后， X_A, X_B 的条件联合分布分解为条件边缘分布的乘积。前一个记号只依赖图，后一个记号依赖概率分布；二者之间的联系需要模型假设。

碰撞点是相对于某一条路径而言的，同一节点在不同路径上可以扮演不同角色。给定其后代也可能传回选择信息，因此不能只检查碰撞点本身是否在条件集。以同时含有

$$X \rightarrow M \rightarrow Y, \quad X \rightarrow C \leftarrow Y, \quad C \rightarrow D$$

的图为例， X, Y 之间有经过 M 和经过 C 的两条路径。四种条件集给出不同判断：

- $S = \emptyset$ ：经过 M 的链活跃，经过 C 的碰撞路径关闭，因而两端仍然 d-连接。
- $S = \{M\}$ ：链被关闭，碰撞路径也仍关闭，所以 $X \perp_g Y \mid M$ 。
- $S = \{M, C\}$ ：链仍关闭，但给定碰撞点打开下方路径，两端重新 d-连接。
- $S = \{M, D\}$ ：给定碰撞点的后代也打开下方路径，两端同样 d-连接。

图 12.4 显示第二种情形。这个例子在本章即可逐路检查；一般路径、分离与图分解的计算工具已在第 9 章建立。




图 12.4 多条路径下的 d-分离。双边框节点 M 属于条件集，上方链式路径关闭；碰撞点 C 及其后代 D 都未给定，下方路径也关闭。若再把 C 或 D 加入条件集，下方路径就会打开，说明增加条件可能破坏原有的分离。

定义 12.22 因果 Markov 性 分布 P 相对于因果 DAG $\mathcal{G}$ 满足因果 Markov 性 (causal Markov property)，是指对任意两两不交的节点集 A, B, S ,

$$A \perp_{\mathcal{G}} B \mid S \implies \mathbf{V}_A \perp \mathbf{V}_B \mid \mathbf{V}_S.$$

其中 $\mathbf{V}_A, \mathbf{V}_B, \mathbf{V}_S$ 分别收集对应节点的随机变量。

左边是图规则，右边是分布性质。因果 Markov 性把前者的阻断结论转成条件独立；它没有说 d-连接一定产生统计依赖，也没有从观测独立直接反推箭头。它与时序过程“给定当前状态后无须更早历史”的 Markov 性质使用不同对象和条件集，不能只因名称相同就互相代入。

对 DAG，这一全局表述等价于局部表述：每个变量在给定父变量后，与其非后代中除自身和父变量外的变量条件独立。独立外生噪声的无环 SCM 满足这一性质。直观上，非后代及父变量不读取当前节点的独立噪声；给定父变量后，当前变量剩下的随机性就来自这一噪声。对局部核乘积，按逆向求值次序逐个积分掉无关后代，每次被消去的条件核积分为一，由此保留所需的局部条件因子。分解与 d-分离的全局对应是 DAG 的标准结论³。图分解与消元工具见第 9 章；把图分离转成概率独立，还需要这里的 DAG 分解或生成机制条件，不能只凭连接结构推出。若背景相关而共同来源没有入图，不能仍对这个省略后的 DAG 直接宣称因果 Markov 性。

³ J. Pearl, *Causality: Models, Reasoning, and Inference*, Cambridge University Press, 2009, 2nd ed.

12.5.3.3 后门条件下的调整变量选择

第 12.4.1.2 节直接假定条件交换性，再证明调整识别。现在可以反过来问：一张已经具有生成语义的图，能否为调整变量的选择提供充分依据？从 T 到 Y 且第一条边指向 T 的路径称为 后门路径 (back-door path)，沿这种

路径离开 T 时, 先走向决定 T 的变量。它反映处理组选择所携带的背景联系, 而不是从处理出发沿箭头传递的结果变化。

定义 12.23 单处理、单结果的后门准则 设 T, Y 是因果 DAG 中的不同节点, Z 与 $\{T, Y\}$ 不交。若 Z 不含 T 的后代, 且给定 Z 阻断所有从 T 到 Y 、第一条边指向 T 的路径, 则称 Z 满足相对于 (T, Y) 的后门准则 (back-door criterion)。

阻断按定义 12.21 判断, 把碰撞点放进 Z 可能打开原本关闭的路径。最基本的代表图为 $Z \rightarrow T, Z \rightarrow Y, T \rightarrow Y$, 独立噪声机制给出

$$p(z, t, y) = p(z)p(t | z)p(y | t, z).$$

将处理机制替换为常量 t 后, $p(z, y | \text{do}(T = t)) = p(z)p(y | t, z)$ 。再对背景积分, 得到

$$p(y | \text{do}(T = t)) = \int p(y | t, z)p(z) dz. \quad (12.39)$$

离散背景用求和, 一般空间用对 P_Z 的核积分。对结果再取期望, 就回到式 (12.22) 的调整表示。

一般后门准则在独立噪声无环 SCM、图正确包含相关共同原因且干预保留其他机制的条件下, 给出同样的调整结论⁴。阻断全部后门路径排除了自然处理选择沿这些路径携带的背景差异, 非后代条件保证用于平均的 Z 不先被行动改变。这些是生成结构对交换性的充分支持, 而不是只由一个观测分布满足 Markov 性就能推出的干预结论。即使图条件成立, 要从观测资料确定积分中的局部响应, 还需要目标总体内所用处理的支持条件; 图不会补出某类背景下从未观察过的处理结果。

⁴ J. Pearl, *Causality: Models, Reasoning, and Inference*, Cambridge University Press, 2009, 2nd ed.

三个局部图可以核对变量角色。在 $T \leftarrow X \rightarrow Y$ 中, X 关闭后门; 在 $T \rightarrow M \rightarrow Y$ 中, M 是后代, 固定它会改变总效应目标; 在 $T \rightarrow C \leftarrow Y$ 中, 空条件集已经关闭碰撞路径, 加入 C 反而打开它。因此, 处理前测量、与结果相关或能提高预测精度, 都不是充分的调整标准。后门准则是充分条件, 不是识别的必要条件; 它不适用时, 随机设计、其他识别规则或更具体的机制假设仍可能确定所选目标。

12.6 因果生成结构的推断

此前给定图和局部机制, 便能生成响应或支持调整。实际研究还可能不知道哪些变量直接相连, 也不知道相连以后怎样传递变化。前一项是变量关系的推断, 后一项是局部机制的推断; 它们共同决定响应, 但所需信息并

不相同。一个模型能拟合观测数据，不代表它的箭头、结构函数和同背景反事实都被唯一确定。

12.6.1 变量关系的推断

从图推出分布约束与从分布反推图，是方向相反的两项任务。要用条件独立排除候选关系，需要说明哪些独立是真正的结构阻断，哪些可能来自参数抵消。数据怎样获得也很重要：按同一自然规则收集的观察记录、受控干预和不同环境中的记录，能够排除的候选模型并不相同。

12.6.1.1 观测资料下的关系识别

若发现两个变量独立，能否据此认定图中没有连接它们的活跃路径？还不能：不同路径的作用可能恰好抵消，使有因果联系的变量仍然独立。要反向使用独立信息，需要先排除这种巧合。

定义 12.24 相对于 DAG 的忠实性 分布 P 相对于 DAG $\mathcal{G}$ 满足忠实性 (faithfulness)，若对任意两两不交的节点集 A, B, S ,

$$V_A \perp V_B \mid V_S \implies A \perp_{\mathcal{G}} B \mid S.$$

忠实性要求分布中出现的条件独立能由图结构解释，不是由特殊参数抵消、确定性约束或未处理的误差相关造成。因果 Markov 性给出正向蕴含，忠实性补上反向蕴含，两者不能互相替代。

例如，设 X, U_M, U_Y 相互独立， $M = \alpha X + U_M$ ， $Y = \beta X + \gamma M + U_Y$ 。当 $\alpha, \gamma \neq 0$ 且 $\beta = -\gamma\alpha$ 时， $Y = \gamma U_M + U_Y$ 与 X 独立，但图中直接路径 $X \rightarrow Y$ 及 $X \rightarrow M \rightarrow Y$ 都存在。两条贡献恰好抵消，说明无环与独立噪声并不自动保证忠实性。接近这种抵消时，非零依赖还可能非常弱，有限样本中难以检出。

只考察三个节点且没有其他路径时，链 $X \rightarrow Z \rightarrow Y$ 、反向链 $X \leftarrow Z \leftarrow Y$ 和共同原因 $X \leftarrow Z \rightarrow Y$ 都蕴含

$$X \perp Y \mid Z,$$

却一般不蕴含 $X \perp Y$ 。条件独立模式无法区分中间变量在传递作用还是造成共同变化。碰撞结构 $X \rightarrow Z \leftarrow Y$ 则蕴含 $X \perp Y$ ，给定中间节点后可能相关；加上忠实性，才能把这种模式差别用作反向辨识的依据。这与图 12.3 的局部规则相呼应；在更大的图中，还必须检查其他路径是否改变独立关系。

定义 12.25 Markov 等价与等价类 同一节点集上的两张 DAG 若具有完全相同的 d-分离关系, 就称它们 Markov 等价(Markov equivalent)。与给定图 Markov 等价的全部 DAG 组成其 Markov 等价类 (Markov equivalence class, MEC)。

图的骨架 (skeleton) 是忽略箭头方向后的邻接关系。无屏蔽碰撞结构 (unshielded collider) 指 $X \rightarrow Z \leftarrow Y$, 并且两端 X, Y 不相邻。没有两端的直接边, 才使这个局部碰撞的差异能够通过两端的分离关系表现出来。标准判据是: 两张 DAG Markov 等价, 当且仅当具有相同骨架和相同无屏蔽碰撞结构⁵。

判据的必要性可以直接从全部路径证明。先说明 DAG 中任意两个非相邻节点都有一个不含端点的 d-分离集。选其中一个节点 v , 使另一个节点 w 不是它的后代; 无环性保证至少有这样一个选择。令条件集为 v 的父节点集。任意从 v 到 w 的路径若第一条边指向 v , 就经过一个父节点; 因两端不相邻, 该父节点是内部非碰撞点, 路径被阻断。若第一条边从 v 向外, 路径不可能一直沿箭头到达非后代 w 。沿路径第一次改变箭头方向时, 出现一个碰撞点 c , 此前的有向前缀说明 c 是 v 的后代。 c 及其任何后代都不可能成为 v 的父节点, 否则形成有向环; 故这个碰撞点没有被条件集打开, 路径仍被阻断。两类覆盖了全部路径。相邻节点之间的单边路径则没有内部点, 不可能被任何不含端点的条件集阻断。因此, 骨架不同必导致 d-分离关系不同。

再考虑同一骨架上的无屏蔽三点结构 $X - Z - Y$ 。两端不相邻, 按上段存在分离集。若 Z 不是碰撞点, 任何分离集都必须包含 Z , 否则长度为二的这条路径仍然活跃; 若 Z 是碰撞点, 任何分离集都不能包含 Z , 否则该路径被打开。因此, 中点碰撞状态不同也必然改变 d-分离关系。其他路径可能增加分离要求, 却不会消除这条长度为二的路径对每个分离集施加的限制。

充分性需要控制所有较长路径, 这里引用完整结构判据, 不把上述必要性论证冒充双向证明⁶。理解等价类内部的方向变化还可借助覆盖边 (covered edge): 边 $X \rightarrow Y$ 若满足

$$\text{pa}(Y) = \text{pa}(X) \cup \{X\},$$

便是覆盖边, 这里 $\text{pa}(X)$ 表示父节点集合。覆盖边反转定理说明, 反转这种边后仍为 DAG, 并保持全部 d-分离关系⁷。从局部因子看, 对给定共同父变量, 这一步把

$$p(x | \text{pa}(X))p(y | x, \text{pa}(X)) = p(y | \text{pa}(X))p(x | y, \text{pa}(X))$$

⁵ D. M. Chickering, *Optimal Structure Identification with Greedy Search* In Journal of Machine Learning Research, 2002, vol. 3, pp. 507-554

⁶ D. M. Chickering, *Optimal Structure Identification with Greedy Search* In Journal of Machine Learning Research, 2002, vol. 3, pp. 507-554

⁷ D. M. Chickering, *Optimal Structure Identification with Greedy Search* In Journal of Machine Learning Research, 2002, vol. 3, pp. 507-554

重新分解，不改变两变量的条件联合分布。因子应取相容的条件版本；这个等式解释分布重参数化，却没有单独证明全图等价，更没有证明两张指定图之间存在变换序列。完整变换定理进一步保证，任意两张已知 Markov 等价的 DAG，可以经有限次覆盖边反转相互到达，每个中间图都保持无环且等价。这是等价类内的可达性结论，不能代替结构判据的充分性证明⁸。

等价类可以用部分有向图表示：全部等价图都同意的方向保留箭头，其余边保持无向。在因果 Markov 性、忠实性、无环和无潜在混杂等条件下，纯观测条件独立信息一般只能识别这样的等价类。输出一条无向边，可能正是在说明：即使总体观测分布完全已知，这条边的方向仍无法确定。增加同分布样本能改善独立性判断，却不会制造类内所缺少的方向信息。

这里还隐含了变量覆盖。所有相关共同原因都已纳入可观测变量时，称满足因果充分性。潜在共同原因能让两个可观测节点相关，却不应被硬解释成其中一个直接导致另一个。允许潜在混杂或选择后，输出往往需要扩大到带不同端点标记的部分图，分别表示已确定的祖先关系、可能方向和无法排除的隐藏共同原因。测量误差以及按碰撞点选择样本也会改变独立模式，不应一律视为新增因果边。

有限样本中的关系发现还要通过检验或评分近似总体判断。以 $H_0 : V_i \perp V_j \mid V_S$ 为原假设，若约束型算法在未拒绝独立时删除候选边，那么第一类错误把真实独立误判为依赖，可能保留虚假边；第二类错误把实际依赖误判为独立，可能删除真实边。后续搜索与定向会传播错误，评分型算法则不能直接套用这组对应。需要控制的变量很多时，具有相近条件的记录可能很少；参数接近作用抵消的情形时，依赖虽不为零，却尤其难以从有限样本中检出。结构学习的一致性必须同时说明总体的 Markov 与忠实条件、检验或评分的渐近性质、候选图范围，以及搜索能否达到目标；一张确定输出图不代表因果方向已经唯一。

12.6.1.2 干预与环境变化下的方向识别

要打破观测方向歧义，需要增加具有不同约束的信息。理想干预切断目标变量的原进入机制：若随机设置 X 后， Y 的分布随设置值改变，在其余机制不变、行动确实只作用于 X 的模型中，这支持 X 位于 Y 的上游。反之，没有观察到分布改变并不自动排除作用，机制抵消、剂量范围或检验能力都可能影响判断。对多个节点施加适当干预可缩小观测等价类，但能缩小到什么程度取决于干预覆盖。

这一证据必须按实际执行解释。干预目标未知、执行不完全，或干预同时改变测量、选择和其他机制时，都应将这些不确定性纳入模型。不能把“鼓励参加培训”无条件等同于“把培训处理设为指定值”，也不能把伴随整套制度改变的干预解释成单个节点的理想替换。

⁸ D. M. Chickering, *Optimal Structure Identification with Greedy Search* In Journal of Machine Learning Research, 2002, vol. 3, pp. 507–554

不同环境也可能提供方向限制。设环境标签为 E ，若假定环境只改变输入 X 的分布，而机制 $Y = f_Y(X, U_Y)$ 及独立噪声 U_Y 的分布保持不变，那么各环境在共同支持上的 $P(Y | X, E = e)$ 应相同；反向条件分布 $P(X | Y, E = e)$ 却可能随输入分布变化。这里稳定性来自已声明的生成假设，并非看到一个稳定条件分布就证明了箭头。

潜在共同原因可以在所有已观察环境中稳定，环境变化也可能太弱，未能打破错误方向；选择规则同步变化还可能制造稳定关联。应分别说明哪些背景分布或局部机制允许改变，哪些保持不变，环境是否直接影响结果，以及稳定性究竟是模型假设、检验对象还是经验线索。机制知识和对隐藏混杂、弱依赖、选择过程的敏感性分析，共同限制候选关系，不能由增加同分布样本替代。

对于反馈环、随时间改变的机制或处理定义不稳定的系统，无环静态模型本身可能不合适，需要改用动态或循环模型并重新定义行动；方向识别不能先忽略模型边界，再用搜索算法的精度弥补。

12.6.2 局部机制的推断

即使关系已经给定，箭头也没有给出作用大小、非线性形状和背景分布。局部机制推断要在声明的函数族、噪声条件和观测制度内估计这些未知部分。它可以回用第 10.5 节的有限维参数或函数估计，但必须先明确估计对象是否具有所需的干预含义。

例如，对已给定的父变量向量 $\mathbf{P}_j$ ，假设局部方程为

$$V_j = \theta_{j0} + \boldsymbol{\theta}_j^\top \mathbf{P}_j + \varepsilon_j, \quad \mathbb{E}[\varepsilon_j | \mathbf{P}_j] = 0.$$

令 $\mathbf{Z}_j = (1, \mathbf{P}_j^\top)^\top$ ，并令 $\boldsymbol{\vartheta}_j = (\theta_{j0}, \boldsymbol{\theta}_j^\top)^\top$ 。若二阶矩有限且 $\mathbf{Q}_j = \mathbb{E}[\mathbf{Z}_j \mathbf{Z}_j^\top]$ 可逆，乘以 $\mathbf{Z}_j$ 再取期望得到

$$\mathbb{E}[\mathbf{Z}_j V_j] = \mathbf{Q}_j \boldsymbol{\vartheta}_j, \quad \boldsymbol{\vartheta}_j = \mathbf{Q}_j^{-1} \mathbb{E}[\mathbf{Z}_j V_j].$$

因此在这些条件下，局部参数可由总体矩识别。独立同分布样本中的对应矩估计为

$$\hat{\boldsymbol{\vartheta}}_j = \left(\frac{1}{n} \sum_{i=1}^n \mathbf{z}_{ij} \mathbf{z}_{ij}^\top \right)^{-1} \left(\frac{1}{n} \sum_{i=1}^n \mathbf{z}_{ij} V_{ij} \right),$$

前提是样本矩可逆。误差、区间和正则化处理仍属于统计估计问题。真实父变量存在确定性共线时，矩方程不能唯一确定各系数；遗漏共同背景造成条件噪声均值非零时，拟合得到的斜率也不再自动等于局部结构参数。

在培训例子里，可以分别拟合技能方程和成绩方程，再复合为 $\hat{\beta} + \hat{\gamma}\alpha$ 。结果方程中的 $\hat{\beta}$ 只是固定技能时的局部系数，不应独自报告为总效应。这样从局部估计传到整体响应时，还须传播多个估计量的共同误差。

非参数情形也要区分三个层次。观测资料可以在父变量支持上估计 $P(V_j | \text{pa}_j)$ ；把这个条件核解释为干预下保持不变的机制，还需要正确关系、噪声及机制不变假设；再要求同一背景下不同输入怎样配对，则需要更强的结构表示。同一组局部条件核可以由不同结构函数和背景耦合实现。第 12.3.1 节的两种跨世界配对已经说明，边缘分布相同不决定已知事实后的替代结果。因此，仅拟合条件分布不能自动唯一恢复个体响应、反事实公平或行动成功概率。

不同的结构函数和背景表示，还可能给出完全相同的观测分布与干预分布。因此一般不能保证从这些分布中唯一恢复 SCM。若采用加性独立噪声、特定函数形状或支持外平滑外推，必须把这些限制写进候选机制类，而不能把拟合优度当成它们已被验证。观测支持外的行动尤其依赖外推，残差诊断也不能单独证明全部背景独立和机制不变。

实际可保留候选对 $(\mathcal{G}, \{f_j\}, P_U)$ ，逐一生成所关心的响应，再把这些答案送回第 12.4.2 节的识别集合。关系不确定、局部参数或函数不确定、跨世界背景配对不确定可能贡献不同范围；样本有限还会增加估计误差。应检查这些不确定性分别怎样改变平均效应、策略价值或补救约束；即使某个模型的拟合最好，也应保留其他同样相容的行动后果。

12.7 本章小结

开篇的培训问题不能只由两组成绩差回答，因为自然接受处理的人可能具有不同背景。给定生成模型和背景分布以后，响应映射能计算主动改变处理的后果；得知某人的事实以后，则先更新背景分布，再在同一背景下改变行动。前者改变生成规则，事实条件化改变对背景的认识，两步不能混成从干预总体重新抽一个人。

不同决策需要不同的比较。同一背景下的结果差描述个体效应，对目标人群平均得到 ATE，按处理前信息分组平均得到 CATE。比较完整结果分布可以检查均值以外的风险，连续处理的导数则描述小幅剂量变化的作用。平均相同不表示无人受益或受损，干预边缘相同也不决定跨世界配对。补救要同时声明目标、可行动变量、成本与成功保证；公平约束还须明确同背景的属性比较及其规范含义。

能够在模型内计算，不等于能够由资料识别。明确的处理版本、一致性和无干扰使目标与实际记录相连，随机分配或条件交换性支持响应识别，支持条件保证资料覆盖目标会使用的协变量-行动组合。调整与逆概率表示是同一目标的不同表达。结构图建立后，后门准则为某些调整选择提供充分依据，却不能代替目标支持，也不是全部识别方法的必要前提。

无法点识别时，有界结果、支持缺口和敏感性约束保留所有相容答案。单调性、效应范围、外推或跨环境稳定可以缩小模型类，但收紧来自这些

新增条件。一般识别集合不必是区间，有效包络也不自动是锐界。识别范围描述总体机制歧义，统计区间描述有限样本误差，积分与优化还有各自的数值误差。增加同分布样本主要改善估计；受控干预、扩大行动覆盖或增加可辩护的机制知识，才可能减少原有识别歧义。缩小目标人群可以改善覆盖，却也改变了要回答的问题。

无环 SCM 把局部函数复合成唯一可测的自然及干预响应，图记录这些函数的输入关系。因果 Markov 性从图推出独立约束，忠实性允许反向使用独立信息；纯观测结构发现通常止于 Markov 等价类，潜在混杂、选择和测量误差还会改变候选范围。关系确定后仍须推断局部机制，观测条件分布拟合又不会自动确定同背景反事实。因此每项结论都应列明目标、行动定义、生成假设、数据收集方式和剩余不确定性。

第 9 章建立的路径、分离和结构分解为这里的图判断提供计算工具，图本身的因果解释则来自本章的机制假设。第 15.4.2 节将单步策略扩展到历史和序贯价值，需要重新检查时变混杂、逐时支持与轨迹目标。第二卷“基础、理论和可信性”的“公平性”章与第二卷“基础、理论和可信性”的“可解释性”章分别回用反事实公平和行动补救，并补充规范要求与现实验证条件。

第五部分

演化、控制、决策与博弈

Evolution, Control, Decision and Games



阅读指引

一台设备的温度会随时间变化。加入加热或散热行动后，怎样让它回到工作温度，怎样控制能耗并避免越过安全线？如果多台设备竞争冷却资源，又该怎样协调？本部分沿这些问题研究状态如何演化、行动如何影响演化，以及如何评价和改进行动规则。稳定、可达、安全、最优和均衡各自回答其中一个问题，需要分别建立条件与结论。

第 13 章“行动和状态”建立确定与随机演化、数值轨迹、稳定性、随机微积分和状态估计。第 14 章“策略的实现与轨迹控制”讨论策略怎样形成闭环，怎样实现可达、稳定、调节、跟踪和安全约束。第 15 章“策略的价值与优化”定义轨迹成本、风险与信息价值，并连接动态规划、策略优化和连续时间价值方程。第 16 章“多方策略的响应与演化”把单方行动扩展到相互响应、均衡、演化稳定和累计表现。

这些章节都使用状态、行动与观测的描述，但所求结论不同：动力学说明会发生什么，控制研究能否实现指定轨迹，价值优化比较不同策略的成本和风险，多方分析继续考察一个人的选择怎样改变其他人的选择。下一部分把这些数学条件重新放回机器学习问题，明确理论保证所依赖的对象和证据。

行动和状态

给房间施加同样的加热量，下一时刻的温度仍取决于房间现在有多热。只记录当前输入，不能预测未来；逐项保存全部加热历史，又未必必要。状态模型在两者之间作出选择：用当前的一组变量概括历史中会影响未来的部分，再规定这些变量怎样更新。第 8 章研究输入与输出之间的信号映射，本章进一步考察这个映射如何产生：过去的影响怎样保留在当前状态中，行动怎样改变状态，以及传感器不能直接测到完整状态时怎样估计它。

本章把行动当作给定输入，不选择行动策略。贯穿例中的状态 x_t 是相对于环境温度的温差，输入 u_t 是加热量，无噪声时满足 $x_{t+1} = 0.8x_t + u_t$ 。给定初值与输入以后，我们先求轨迹，继而判断扰动是否消退；加入过程噪声，我们需要描述各种可能的轨迹及其概率；再获得传感器读数后，就可以利用读数更新对状态的判断，得到给定观测时的条件分布。在有噪声的模型中，给定输入也可能产生不同的状态轨迹。若只关心某一时刻的温度，就计算该时刻的边缘分布；若还关心不同时刻的温度怎样关联，就计算联合分布。传感器读数又提供了新的信息：据此更新得到的状态分布称为后验分布。因此，后文选择数值方法时，会区分是在近似一条轨迹、状态分布，还是利用观测估计当前状态。

13.1 行动与状态的演化模型

13.1.1 状态、输入与初始条件

状态是模型中足以预测下一步演化的当前信息，不必是全部可见数据，也不必逐项保存历史。以温度为例，在固定环境与采样间隔下，取状态空间为 $\mathbb{R}$ ，给定初值 $x_0 = 0$ ，并持续施加 $u_t = 0.4$ ，则最初几步为

$$x_1 = 0.4, \quad x_2 = 0.72, \quad x_3 = 0.976.$$

这里的系数 0.8 表示前一时刻温差保留下来的比例；其余影响由输入补充。恒定状态 $r = 2$ 所需的输入恰为 $r - 0.8r = 0.4$ 。这只是给定输入下的平衡核对，并未根据当前温度改变行动。

状态的选择依赖模型。若墙体蓄热显著影响下一步室温，而当前室温无法概括它，就要增加墙体温度等状态；若传感器有滞后，还应区分房间状态与传感器内部状态。所谓“当前状态足够”，是一项需要验证的建模要求，不是把某个变量命名为状态后自动获得的性质。

初始条件规定轨迹从哪里开始，输入规定沿途施加什么作用，演化规律规定这些作用怎样改变状态。输出则是模型对外显示的量。无噪声且传感器直接测温时可以有 $y_t = x_t$ ，但一般输出只给状态的部分信息。后文恢复过程噪声与观测噪声时，仍使用同一时序：时刻 t 的状态已经形成，传感器产生 y_t ，然后给定的 u_t 把状态推向 $t + 1$ 。只有在控制问题中，才进一步规定如何依据这些信息选择 u_t 。

13.1.2 离散时间的状态更新

设 $\mathcal{X}$ 是允许的状态集合， $\mathcal{U}$ 是输入集合。一步更新映射

$$F_t : \mathcal{X} \times \mathcal{U} \longrightarrow \mathcal{X}, \quad \mathbf{x}_{t+1} = F_t(\mathbf{x}_t, \mathbf{u}_t)$$

直接规定下一状态。只要初值属于 $\mathcal{X}$ 、每个输入属于 $\mathcal{U}$ ，且映射确实把状态送回 $\mathcal{X}$ ，有限步递推便有定义。若只在某个区域内给出公式，则每一步还要检查结果是否留在该区域。本章的温度例暂不限制输入或状态的取值范围。

线性模型常写为

$$\mathbf{x}_{t+1} = \mathbf{A}_t \mathbf{x}_t + \mathbf{B}_t \mathbf{u}_t, \quad \mathbf{x}_t \in \mathbb{R}^d, \quad \mathbf{u}_t \in \mathbb{R}^m.$$

它关于状态与输入的联合变量是线性的；固定非零输入后，它关于状态通常是仿射的。矩阵不随 t 改变称为时不变，显式随 t 改变则称为时变。是否线性与是否时变是两项独立性质。若 $\mathbf{A}_t$ 还依赖当前状态或输入，虽然公式仍有“矩阵乘状态”的外形，整体映射通常已不是线性的。

为了看清新输入与已有状态分别起什么作用，可以使用一个带泄漏的记忆模型。这里“泄漏”表示旧输入留下的影响会逐步减弱：

$$x_{t+1} = ax_t + bu_t, \quad x_0 \text{ 给定}. \quad (13.1)$$

温度例对应 $a = 0.8, b = 1$ 。系数 a 控制已有信息保留多少， b 控制新输入进入多少。能逐步计算并不说明长期状态有界；同一公式取 $|a| > 1$ 便能放大早期扰动。

13.1.3 连续时间的状态变化

若关注相邻采样时刻之间发生了什么，需要规定瞬时变化率，而不仅是相隔一步的差值。常微分方程（ordinary differential equation, ODE）初值问题写为

$$\dot{\mathbf{x}}(t) = \mathbf{f}(t, \mathbf{x}(t), \mathbf{u}(t)), \quad \mathbf{x}(t_0) = \mathbf{x}_0. \quad (13.2)$$

给定输入后，右侧是作用在当前状态上的向量场。若它不显含时间，称方程为自治的；否则为非自治的。恒定矩阵配上随时间变化的外部输入，也会产生非自治方程。向量场告诉我们“现在往哪里、以多快速度移动”，有限时间转移还要由积分确定。

例如把泄漏记忆在小间隔 Δt 上的系数写为 $a = 1 - \lambda\Delta t$ 、 $b = \Delta t$ ，形式上有

$$\frac{x_{t+\Delta t} - x_t}{\Delta t} = -\lambda x_t + u_t.$$

若极限成立，对应模型为

$$\dot{x}(t) = -\lambda x(t) + u(t). \quad (13.3)$$

这说明连续变化率怎样导出一种离散近似，而不是说明任意离散系数都与某个连续模型天然等价。贯穿例中的 0.8 对应原先规定的一个采样间隔；改变采样间隔后，需要重新计算一步系数，不能直接沿用它。

温度例中，已有温差会随时间减小。无摩擦的力学运动则提出另一种建模要求：动能与势能可以相互转换，而总能量保持不变。只知道位置仍不足以预测运动，因为同一位置上的物体可以向不同方向运动。因此，下面同时记录位置与动量，用它们描述运动状态；这些状态组成的空间称为相空间。

定义 13.1 可分 Hamilton 系统 令 $\mathbf{q}, \mathbf{p} \in \mathbb{R}^d$ 分别为位置与动量， U 为连续可微的势能， $\mathbf{M}$ 为对称正定的质量矩阵。可分 Hamilton 量为

$$H(\mathbf{q}, \mathbf{p}) = U(\mathbf{q}) + \frac{1}{2} \mathbf{p}^\top \mathbf{M}^{-1} \mathbf{p}. \quad (13.4)$$

相应的 Hamilton 方程为

$$\dot{\mathbf{q}} = \nabla_{\mathbf{p}} H, \quad \dot{\mathbf{p}} = -\nabla_{\mathbf{q}} H. \quad (13.5)$$

第一式由动量得到位置速度，第二式由势能坡度得到动量变化。令 $\mathbf{z} = (\mathbf{q}^\top, \mathbf{p}^\top)^\top$ ，则方程也可写为

$$\dot{\mathbf{z}} = \mathbf{J} \nabla H(\mathbf{z}), \quad \mathbf{J} = \begin{bmatrix} \mathbf{0} & \mathbf{I} \\ -\mathbf{I} & \mathbf{0} \end{bmatrix}.$$

它不是沿 $-\nabla H$ 下降, 而是把梯度转换为成对坐标之间的运动方向。例如 $U(q) = q^2/2, M = 1$ 给出 $\dot{q} = p, \dot{p} = -q$, 位置和动量相互影响, 势能与动能交替转换。轨迹是否唯一、能量是否保持、怎样数值推进, 将分别在相应条件下证明。

13.2 状态轨迹的求解与计算

模型给出局部规则, 轨迹则把这些规则接续起来。离散时间可以有限次复合; 连续时间需要先证明积分方程有解。轨迹确定以后, 才能讨论历史输入的贡献、保守运动的几何以及计算误差。以下各项都固定初值与输入, 不把未知观测混入求解条件。

13.2.1 给定初值与输入的轨迹求解

13.2.1.1 离散时间下的轨迹递推

把给定输入吸收进 $F_t^u(x) = F_t(x, u_t)$, 前两步为

$$x_1 = F_0^u(x_0), \quad x_2 = F_1^u(F_0^u(x_0)).$$

一般状态是有序复合 $x_t = (F_{t-1}^u \circ \cdots \circ F_0^u)(x_0)$ 。较晚更新写在左边, 因为它作用于较早更新的结果; 调换复合顺序会改变系统。

泄漏模型可进一步展开:

$$x_t = a^t x_0 + \sum_{j=0}^{t-1} a^{t-1-j} b u_j. \quad (13.6)$$

证明从 $t = 0$ 的空和开始。若式子对 t 成立, 两边乘 a 再加 $b u_t$, 便得到 $t+1$ 的式子。初值与每次输入的贡献都在其中: 旧输入经历的更新次数更多, 因而多乘若干个 a 。

先用泄漏模型查看一次输入如何留下逐步减弱的影响。为便于手算, 这个算例暂取 $a = 1/2, b = 1, x_0 = 0$ 。仅在第零步输入 $u_0 = 1$ 时, $x_1 = 1, x_2 = 1/2, x_3 = 1/4$; 若 $u_0 = u_1 = 1$, 则 $x_2 = 3/2$, 其中 $1/2$ 来自旧输入, 1 来自新输入。这就是状态保存的历史总作用。回到温度例, $u_t = 0.4$ 给出

$$x_t = 2 + 0.8^t(x_0 - 2).$$

有限步展开已经得到轨迹; 它趋于 2 还使用了 $|0.8| < 1$ 。一般非线性映射可逐步计算, 却未必有这样的闭式或极限。

13.2.1.2 连续时间下的轨迹存在与延拓

给出几乎处处的斜率后，我们希望能把斜率积分回原曲线。但对一般连续曲线，导数可能遗漏一部分变化，积分后无法恢复原曲线。因此需要把解限制为能够由可积斜率完整恢复的曲线，这就是下面的绝对连续曲线。

定义 13.2 绝对连续曲线 有限区间 $[a, b]$ 上的曲线 $\mathbf{x} : [a, b] \rightarrow \mathbb{R}^d$ 称为绝对连续曲线，若存在 $\mathbf{v} \in L^1([a, b]; \mathbb{R}^d)$ ，使 $\mathbf{x}(t) = \mathbf{x}(a) + \int_a^t \mathbf{v}(s) ds$ 对每个 t 成立。此时 $\dot{\mathbf{x}} = \mathbf{v}$ 几乎处处成立。

记 $\mathbf{g}(t, \mathbf{x}) = \mathbf{f}(t, \mathbf{x}, \mathbf{u}(t))$ 。积分意义下的解就是满足

$$\mathbf{x}(t) = \mathbf{x}_0 + \int_{t_0}^t \mathbf{g}(s, \mathbf{x}(s)) ds \quad (13.7)$$

的绝对连续曲线。当 $\mathbf{g}$ 连续时，它还是处处满足微分方程的经典解。

定理 13.3 局部存在唯一性 若给定输入后的 $\mathbf{g}$ 在 $(t_0, \mathbf{x}_0)$ 附近连续，且关于状态局部 Lipschitz，Lipschitz 常数可在该时间邻域内统一选取，则存在包含 t_0 的区间，使式 (13.2) 有唯一局部解。

证明. 在适用邻域内选闭区域

$$D = [t_0 - a, t_0 + a] \times \{\mathbf{x} : \|\mathbf{x} - \mathbf{x}_0\|_2 \leq b\}.$$

紧性给出 $M = \sup_D \|\mathbf{g}\|_2 < \infty$ ；记统一 Lipschitz 常数为 L 。选 $h > 0$ 使 $h \leq a, Mh \leq b, Lh < 1$ 。在 $I = [t_0 - h, t_0 + h]$ 上，

$$\mathcal{X} = \{\mathbf{z} \in C(I, \mathbb{R}^d) : \|\mathbf{z} - \mathbf{x}_0\|_\infty \leq b\}$$

是完备空间的闭子集，因而完备。定义 $(\mathcal{T}\mathbf{z})(t) = \mathbf{x}_0 + \int_{t_0}^t \mathbf{g}(s, \mathbf{z}(s)) ds$ 。对 $\mathbf{z} \in \mathcal{X}$ ， $\|(\mathcal{T}\mathbf{z})(t) - \mathbf{x}_0\|_2 \leq M|t - t_0| \leq Mh \leq b$ ，所以 $\mathcal{T}$ 映回 $\mathcal{X}$ 。同时

$$\|\mathcal{T}\mathbf{z}_1 - \mathcal{T}\mathbf{z}_2\|_\infty \leq Lh\|\mathbf{z}_1 - \mathbf{z}_2\|_\infty.$$

压缩映射定理给出唯一不动点，即积分方程的解。任何同初值的局部解在足够短的区间内都落在 $\mathcal{X}$ ，故与此解重合；在共同存在区间逐段重复便得到局部唯一性。 ■

这个证明把三种条件分开使用：连续性给出有界的局部变化率，完备性让迭代的极限仍是候选曲线，统一 Lipschitz 条件使积分算子在短区间收

缩。只有连续性不保证唯一性。例如 $\dot{x} = \sqrt{|x|}$, $x(0) = 0$ 既有零解, 也有对任意 $c \geq 0$ 定义的

$$x(t) = \begin{cases} 0, & 0 \leq t \leq c, \\ (t-c)^2/4, & t > c. \end{cases}$$

解可以任意等待后再离开原点。

局部解能通过重叠区间的唯一性接成长一些解。不能再向外接续的解称为最大解; 若最大解的存在区间包含研究所需的全部时刻, 就得到了相应全局解。局部光滑仍可能有限时间爆炸: $\dot{x} = x^2$, $x(0) = 1$ 的解 $x(t) = 1/(1-t)$ 在 $t = 1$ 前已无界。排除这种情况, 需要增长控制。下面的估计也是后文比较两条轨迹的共同工具。

引理 13.4 Grönwall 积分估计 设 e 为 $[a, T]$ 上非负连续函数, b 为非负可积函数。若

$$e(t) \leq c + \int_a^t b(s)e(s) ds, \quad c \geq 0,$$

则 $e(t) \leq c \exp(\int_a^t b(s) ds)$ 。更一般地, 若右侧另有 $\int_a^t r(s) ds$, 其中 $r \geq 0$ 可积, 则

$$e(t) \leq c e^{\int_a^t b} + \int_a^t r(s) e^{\int_s^t b} ds.$$

证明. 令 $E(t) = c + \int_a^t [b(s)e(s) + r(s)] ds$, 则 $e \leq E$, 且 $E' \leq bE + r$ 几乎处处成立。乘以绝对连续的积分因子 $\exp(-\int_a^t b)$, 使用乘积法则并从 a 积分到 t , 得

$$E(t)e^{-\int_a^t b} \leq c + \int_a^t r(s)e^{-\int_a^s b} ds.$$

再乘回积分因子并用 $e \leq E$ 即可; 取 $r = 0$ 得到第一式。■

若 $\|g(t, \mathbf{x})\| \leq b(t)\|\mathbf{x}\| + r(t)$, 其中 b, r 在每个有限时间区间可积, 积分方程与此引理给出有限的状态上界。在局部存在条件持续有效、状态域为 $\mathbb{R}^d$ 时, 这排除了有限时间逃逸, 因而最大解可延拓到任意有限时刻。全局 Lipschitz 以及 $\|g(t, \mathbf{0})\|$ 的局部可积性是常用的充分条件。输入若关于时间可测而不连续, 局部存在与唯一性需要改用相应的 Carathéodory 条件: g 关于时间可测、关于状态连续, 并在紧状态集上有可积上界与可积 Lipschitz 系数。这些条件控制了不连续输入造成的变化, 使积分形式的求解仍有依据; 输入不可测时, 本段的存在性结论不适用。

13.2.2 历史输入的传播与表示

一个已经给定的状态递推怎样传播旧输入，与怎样设计状态来近似一段历史，是两个方向相反的问题。前者展开已有方程，后者选择要保存的坐标。线性传播和投影分别使这两个问题可计算。

13.2.2.1 线性状态下的历史输入传播

先保持离散时间。对时不变系统，允许输出还直接依赖当前输入：

$$\begin{aligned} \mathbf{x}_{t+1} &= \mathbf{A}\mathbf{x}_t + \mathbf{B}\mathbf{u}_t, \\ \mathbf{y}_t &= \mathbf{C}\mathbf{x}_t + \mathbf{D}\mathbf{u}_t. \end{aligned} \quad (13.8)$$

这里 $\mathbf{A} \in \mathbb{R}^{d \times d}$ 、 $\mathbf{B} \in \mathbb{R}^{d \times m}$ 、 $\mathbf{C} \in \mathbb{R}^{p \times d}$ 、 $\mathbf{D} \in \mathbb{R}^{p \times m}$ 。本章统一用 $\mathbf{x}$ 表示状态、 $\mathbf{u}$ 表示输入；信号表示中的输入记号不能在这里继续兼作状态。直接项 $\mathbf{D}\mathbf{u}_t$ 是本小节允许的一般输出通道，贯穿温度传感器模型则取 $\mathbf{D} = \mathbf{0}$ ，不改变“先读数、后输入推动下一状态”的时序。

前两步为 $\mathbf{x}_1 = \mathbf{A}\mathbf{x}_0 + \mathbf{B}\mathbf{u}_0$ 及 $\mathbf{x}_2 = \mathbf{A}^2\mathbf{x}_0 + \mathbf{A}\mathbf{B}\mathbf{u}_0 + \mathbf{B}\mathbf{u}_1$ 。归纳得到

$$\mathbf{x}_t = \mathbf{A}^t \mathbf{x}_0 + \sum_{\tau=0}^{t-1} \mathbf{A}^{t-1-\tau} \mathbf{B} \mathbf{u}_\tau. \quad (13.9)$$

归纳步把右侧乘 $\mathbf{A}$ 并加 $\mathbf{B}\mathbf{u}_t$ ，求和上界与各项幂次就同时前移一格。代入输出方程，

$$\mathbf{y}_t = \mathbf{C}\mathbf{A}^t \mathbf{x}_0 + \mathbf{D}\mathbf{u}_t + \sum_{\tau=0}^{t-1} \mathbf{C}\mathbf{A}^{t-1-\tau} \mathbf{B} \mathbf{u}_\tau. \quad (13.10)$$

第一项是初态的自由响应，其余项是输入响应。零初态时，定义

$$\mathbf{K}_0 = \mathbf{D}, \quad \mathbf{K}_r = \mathbf{C}\mathbf{A}^{r-1}\mathbf{B} \quad (r \geq 1), \quad (13.11)$$

就得到因果卷积 $\mathbf{y}_t = \sum_{\tau=0}^t \mathbf{K}_{t-\tau} \mathbf{u}_\tau$ 。核 $\mathbf{K}_r$ 记录 r 步以前的输入经过剩余状态传播后对当前输出的作用。非零初态的自由响应必须另加，不能塞进一个与输入无关的零状态卷积公式。

沿用前面便于手算的泄漏模型，取 $a = 1/2, b = c = 1, d = 0, x_0 = 0$ ，并直接把状态作为输出。依次输入 $u_0 = 1, u_1 = 2, u_2 = 1$ ，递推给出 $y_0 = 0, y_1 = 1, y_2 = 5/2, y_3 = 9/4$ 。核为 $K_0 = 0, K_1 = 1, K_2 = 1/2, K_3 = 1/4$ ，所以

$$y_3 = K_3 u_0 + K_2 u_1 + K_1 u_2 = \frac{1}{4} + 1 + 1 = \frac{9}{4}.$$

严格因果的状态通道使 $y_0 = 0$ ；若 $d \neq 0$ ，当前输入还会立即通过 $K_0 = d$ 进入输出。标量核 $ca^{r-1}b$ 在 $|a| < 1$ 时几何衰减，在 $|a| > 1$ 时增长；多维状态还需检查不同方向的传播，不能由核的形式本身断言稳定。

时变系统用有序乘积

$$\Phi(t, s) = A_{t-1} \cdots A_s \quad (t > s), \quad \Phi(s, s) = I$$

描述没有输入时状态从 s 到 t 的变化。利用它, 含输入的状态可写为

$$\mathbf{x}_t = \Phi(t, 0)\mathbf{x}_0 + \sum_{\tau=0}^{t-1} \Phi(t, \tau+1)\mathbf{B}_\tau \mathbf{u}_\tau.$$

若输出为 $\mathbf{C}_t \mathbf{x}_t + \mathbf{D}_t \mathbf{u}_t$, 对应核为

$$\mathbf{K}_{t,t} = \mathbf{D}_t, \quad \mathbf{K}_{t,\tau} = \mathbf{C}_t \Phi(t, \tau+1) \mathbf{B}_\tau \quad (\tau < t).$$

它依赖两个绝对时刻, 通常不只依赖滞后 $t - \tau$, 所以线性仍在, 平移不变性却已消失。较晚矩阵必须置于左边。若这些矩阵还依赖输入或状态, 展开系数也随输入轨迹改变, 叠加通常失效; 固定轨迹附近的线性化核仅有局部含义。

连续时间对应的时不变方程是

$$\dot{\mathbf{x}}(t) = \mathbf{A}\mathbf{x}(t) + \mathbf{B}\mathbf{u}(t). \quad (13.12)$$

矩阵指数的导数见第6章。令 $\mathbf{z}(t) = e^{-t\mathbf{A}}\mathbf{x}(t)$, 乘积求导给出 $\dot{\mathbf{z}}(t) = e^{-t\mathbf{A}}\mathbf{B}\mathbf{u}(t)$ 。积分并乘回指数, 得到

$$\mathbf{x}(t) = e^{(t-t_0)\mathbf{A}}\mathbf{x}_0 + \int_{t_0}^t e^{(t-s)\mathbf{A}}\mathbf{B}\mathbf{u}(s) ds. \quad (13.13)$$

代入 t_0 得到初值; 对积分上限求导得到原方程, 因而这确实是解, 而非只是一种形式展开。局部可积输入给出积分意义的解, 连续输入给出经典解。标量泄漏模型取 $\lambda > 0, u(t) \equiv u_0$ 时,

$$x(t) = e^{-\lambda(t-t_0)}x_0 + \frac{1 - e^{-\lambda(t-t_0)}}{\lambda}u_0.$$

初值作用消退, 持续输入则留下 u_0/λ , 两种贡献不能一起称为“趋零”。

时变系数需要连续时间的传播算子。

定义 13.5 状态转移矩阵 对连续矩阵函数 $\mathbf{A}(t)$, 状态转移矩阵 $\Phi(t, s)$ 是满足

$$\partial_t \Phi(t, s) = \mathbf{A}(t)\Phi(t, s), \quad \Phi(s, s) = I \quad (13.14)$$

的矩阵值解。它把时刻 s 的齐次初态映到时刻 t 。

由解的唯一性, $\Phi(t, r)\Phi(r, s) = \Phi(t, s)$ 。反向传播给出 $\Phi(t, s)^{-1} = \Phi(s, t)$; 用该逆矩阵作积分因子, 得到

$$\mathbf{x}(t) = \Phi(t, t_0)\mathbf{x}_0 + \int_{t_0}^t \Phi(t, s)\mathbf{B}(s)\mathbf{u}(s) ds. \quad (13.15)$$

对输出 $\mathbf{C}(t)\mathbf{x}(t) + \mathbf{D}(t)\mathbf{u}(t)$, 连续历史核是 $\mathbf{C}(t)\Phi(t, s)\mathbf{B}(s)$, 直接项仍单列。时不变时它退化为滞后核 $\mathbf{C}e^{(t-s)\mathbf{A}}\mathbf{B}$ 。

一般不能令 $\Phi(t, s) = \exp(\int_s^t \mathbf{A}(r) dr)$ 。例如先运行常矩阵 $\mathbf{A}_1$ 一单位时间, 再运行 $\mathbf{A}_2$ 一单位时间, 实际传播为 $e^{\mathbf{A}_2}e^{\mathbf{A}_1}$, 非交换时不等于 $e^{\mathbf{A}_1+\mathbf{A}_2}$ 。只有不同时间矩阵彼此交换等附加条件成立时, 才能把时序传播压成普通矩阵指数。

13.2.2.2 有限维状态下的历史窗口表示

另一种构造从希望保留的历史特征出发。例如为一段输入保留平均值与线性趋势, 就可把投影坐标当作状态。设随 t 改变的内积为

$$\langle f, g \rangle_t = \int_0^t f(s)g(s)w_t(s) ds,$$

并选基 $\phi_1^{(t)}, \dots, \phi_d^{(t)}$ 。若基正交归一, $c_i(t) = \langle u, \phi_i^{(t)} \rangle_t$ 就是展开系数; 一般基则要先构造 $G_{i,j}(t) = \langle \phi_i^{(t)}, \phi_j^{(t)} \rangle_t$, 再由 $\mathbf{G}(t)\mathbf{a}(t) = \mathbf{c}(t)$ 得到投影坐标 $\mathbf{a}(t)$ 。分析坐标 $\mathbf{c}$ 和投影坐标 $\mathbf{a}$ 不能在非正交基下混用。

窗口本身移动时, 状态变化不全来自新输入。固定宽度 $T > 0$, 写

$$c_\ell(t) = \int_{t-T}^t u(s)\phi_\ell(t, s)w(t, s) ds.$$

在被积函数及所需偏导连续等 Leibniz 求导条件下,

$$\begin{aligned} \dot{c}_\ell(t) &= u(t)\phi_\ell(t, t)w(t, t) - u(t-T)\phi_\ell(t, t-T)w(t, t-T) \\ &\quad + \int_{t-T}^t u(s)\partial_t[\phi_\ell(t, s)w(t, s)] ds. \end{aligned} \quad (13.16)$$

这三项分别来自右端新输入、左端旧输入退出, 以及窗口内部基或权重的改变。漏掉左端项, 就把固定长度窗口误当成只增长不遗忘的历史。

取均匀权重下的常数与一次矩,

$$c_0(t) = \frac{1}{T} \int_{t-T}^t u(s) ds, \quad c_1(t) = \frac{2}{T^2} \int_{t-T}^t (s-t+T)u(s) ds,$$

上式给出

$$\dot{c}_0(t) = \frac{u(t) - u(t-T)}{T}, \quad \dot{c}_1(t) = \frac{2}{T}u(t) - \frac{2}{T}c_0(t).$$

第二式只需要当前保存的坐标和当前输入，就能计算变化率；第一式还需要已经移到窗口左端的旧输入。所以有限个历史特征不自动形成能独立接续演化的有限维状态；需要额外状态、特别的基与权重，或对边界项作近似。

用历史投影构造状态时，需要同时回答三个问题：这些坐标能保留哪些历史特征，下一步能否只用已有坐标与新输入更新，以及更新会不会放大扰动。HiPPO 一类方法通过选择窗口、权重与基来设计这样的状态坐标。投影误差回答的是第一个问题：在选定的度量下，有限坐标能把历史近似到什么程度。它并不表示所有历史信息都被无损保存；更新能否独立完成以及更新是否稳定，仍需另外检查。

13.2.3 保守轨迹的能量与结构保持

泄漏模型会减弱旧状态的作用，Hamilton 模型则允许状态持续运动而保持某些量。下面先考察精确解。只有知道原轨迹应保持什么，才能判断数值方法保存了什么、破坏了什么。

13.2.3.1 精确轨迹的能量守恒

定理 13.6 Hamilton 能量守恒 若 H 连续可微、不显含时间，且 Hamilton 方程的解在所考察区间存在，则

$$H(\mathbf{q}(t), \mathbf{p}(t)) = H(\mathbf{q}(0), \mathbf{p}(0)).$$

证明. 沿解使用链式法则和式 (13.5),

$$\frac{dH}{dt} = \nabla_{\mathbf{q}} H^\top \dot{\mathbf{q}} + \nabla_{\mathbf{p}} H^\top \dot{\mathbf{p}} = \nabla_{\mathbf{q}} H^\top \nabla_{\mathbf{p}} H - \nabla_{\mathbf{p}} H^\top \nabla_{\mathbf{q}} H = 0.$$

积分即得结论。 ■

因此轨迹被限制在初始能量面上，而不是向能量极小值下降。若 H 显含时间，同一计算只给出 $dH/dt = \partial_t H$ 。守恒本身也不保证全局存在或位置有界：自由粒子 $H = p^2/2$ 保持动量与能量，但 $p \neq 0$ 时 $q(t) = q(0) + pt$ 没有界。只有能量量子水平集紧、向量场局部存在条件持续有效等附加条件，才可利用守恒排除有限时间逃逸。

13.2.3.2 精确轨迹的辛结构与体积保持

能量只给轨迹上的标量限制，仍未说明一小团相邻初态怎样变形。为比较方向之间的关系，取相空间坐标 $\mathbf{z} = (\mathbf{q}^\top, \mathbf{p}^\top)^\top$ 及前述矩阵 $\mathbf{J}$ 。

定义 13.7 标准辛形式与辛映射 对 $\mathbf{u}, \mathbf{v} \in \mathbb{R}^{2d}$ ，标准辛形式为 $\omega(\mathbf{u}, \mathbf{v}) = \mathbf{u}^\top \mathbf{J} \mathbf{v}$ 。若 C^1 映射 ψ 在定义域每一点的 Jacobian 矩阵 $\mathbf{G} = \nabla \psi$ 满足

$$\mathbf{G}^\top \mathbf{J} \mathbf{G} = \mathbf{J}, \quad (13.17)$$

则称其为辛映射。

该等式表示任意两方向经映射后具有相同的辛形式值。一个位置和一个动量时，它就是有向面积；多对坐标时，它还约束共轭方向之间的配对，强于只记录总体积。

设 $H \in C^2$ 、 $\mathbf{F} = \mathbf{J} \nabla H$ 。把初态 $\mathbf{z}_0$ 映到时刻 t 状态的映射记为 $\varphi_t(\mathbf{z}_0) = \mathbf{z}(t; \mathbf{z}_0)$ ，称为精确流（exact flow）。以下限制在所考察初态邻域内的解共同存在的局部时间区间。固定 t 时，这个映射的自变量是初态； C^1 向量场使它对初态可微。记 $\mathbf{G}_t = \nabla \varphi_t(\mathbf{z}_0)$ ，它把初态的小扰动转成当前状态的一阶扰动。对积分方程关于初值求导得到变分方程

$$\dot{\mathbf{G}}_t = \nabla \mathbf{F}(\mathbf{z}(t)) \mathbf{G}_t, \quad \mathbf{G}_0 = \mathbf{I}.$$

初始映射 φ_0 是恒等映射，所以 $\mathbf{G}_0 = \mathbf{I}$ 。反向时间的唯一解给出流的局部逆，所以 $\mathbf{G}_t$ 可逆。由 Jacobi 行列式公式，

$$\frac{d}{dt} \log |\det \mathbf{G}_t| = \text{tr}(\nabla \mathbf{F}) = \text{tr}(\mathbf{J} \nabla^2 H) = 0.$$

最后一个等号来自反对称矩阵与对称矩阵的乘积迹为零。初始行列式为 1，故 $\det \mathbf{G}_t = 1$ ，精确流保持相空间体积及其定向。

还可直接验证更强的辛性。写 $\mathbf{S} = \nabla^2 H = \mathbf{S}^\top$ ，则

$$\begin{aligned} \frac{d}{dt} (\mathbf{G}_t^\top \mathbf{J} \mathbf{G}_t) &= \mathbf{G}_t^\top [(\mathbf{J} \mathbf{S})^\top \mathbf{J} + \mathbf{J}(\mathbf{J} \mathbf{S})] \mathbf{G}_t \\ &= \mathbf{G}_t^\top (\mathbf{S} - \mathbf{S}) \mathbf{G}_t = \mathbf{0}. \end{aligned}$$

初值为 $\mathbf{J}$ ，所以精确流满足式 (13.17)。对该式取行列式也给出 $(\det \mathbf{G}_t)^2 = 1$ ，结合从恒等映射连续出发，再次得到 $\det \mathbf{G}_t = 1$ 。

反向推断却不成立。在 (q_1, q_2, p_1, p_2) 坐标下， $\text{diag}(2, 1, 1, 1/2)$ 的行列式为 1，但它把第一对位置动量的面积乘以 2，第二对乘以 1/2，不保持标准辛形式。总体积不变允许不同配对之间互相抵消；辛性不允许这种抵消代替各方向对的结构。

13.2.4 连续轨迹的离散计算

已知轨迹存在唯一，不代表能写出解析式。记从 t_n 到 $t_{n+1} = t_n + h$ 的精确流为 φ_{t_{n+1}, t_n} ，数值方法以可计算的一步映射 Ψ_{h, t_n} 近似它。从精确起点出发，两映射的差称为一步局部误差；反复使用数值起点后， $\hat{\mathbf{x}}_n - \mathbf{x}(t_n)$ 才是全局误差。自治方程中可以把流简写为 φ_h ，非自治时不能省去起始时刻的影响。

13.2.4.1 一般状态下的数值近似

显式 Euler 法在一步内使用当前斜率：

$$\hat{\mathbf{x}}_{n+1} = \hat{\mathbf{x}}_n + h\mathbf{f}(t_n, \hat{\mathbf{x}}_n). \quad (13.18)$$

这里已把给定输入吸收进 $\mathbf{f}$ 。Euler 法用起点的斜率近似整步变化；若斜率在这一步内变化明显，这个近似就会产生较大误差。经典四阶 Runge-Kutta 法改为估计起点、中点和终点附近的斜率，再按权重组合，以更准确地近似这一步的变化：

$$\begin{aligned} \mathbf{k}_1 &= \mathbf{f}(t_n, \hat{\mathbf{x}}_n), \\ \mathbf{k}_2 &= \mathbf{f}(t_n + h/2, \hat{\mathbf{x}}_n + h\mathbf{k}_1/2), \\ \mathbf{k}_3 &= \mathbf{f}(t_n + h/2, \hat{\mathbf{x}}_n + h\mathbf{k}_2/2), \\ \mathbf{k}_4 &= \mathbf{f}(t_n + h, \hat{\mathbf{x}}_n + h\mathbf{k}_3), \\ \hat{\mathbf{x}}_{n+1} &= \hat{\mathbf{x}}_n + \frac{h}{6}(\mathbf{k}_1 + 2\mathbf{k}_2 + 2\mathbf{k}_3 + \mathbf{k}_4). \end{aligned}$$

在足够光滑、有限时间及适当 Lipschitz 条件下，两者全局误差分别为 $O(h)$ 和 $O(h^4)$ 。较高阶意味着局部近似利用更多信息，也意味着每步更多函数评估；不能只按步数比较成本。¹

¹ E. Hairer, S. P. Nørsett, G. Wanner, *Solving Ordinary Differential Equations I: Nonstiff Problems*, Springer, 1993, 2nd ed.

定理 13.8 Euler 法的有限时域全局误差 设 $\mathbf{f}$ 在包含精确轨迹与 Euler 轨迹的区域内关于状态具有 Lipschitz 常数 L ，精确解二阶连续可微，且 $\|\ddot{\mathbf{x}}(t)\|_2 \leq M$ 。从精确初值出发，若 $t_n = t_0 + nh \leq t_0 + T$ ，则 $L > 0$ 时

$$\|\hat{\mathbf{x}}_n - \mathbf{x}(t_n)\|_2 \leq \frac{Mh}{2L}(e^{LT} - 1).$$

$L = 0$ 时相应上界为 $MTh/2$ 。

证明. Taylor 公式给出 $\mathbf{x}(t_{n+1}) = \mathbf{x}(t_n) + h\mathbf{f}(t_n, \mathbf{x}(t_n)) + \tau_n$ ，其中 $\|\tau_n\|_2 \leq Mh^2/2$ 。记 $\mathbf{e}_n = \hat{\mathbf{x}}_n - \mathbf{x}(t_n)$ ，相减并用 Lipschitz 条件得

$$\|\mathbf{e}_{n+1}\|_2 \leq (1 + Lh)\|\mathbf{e}_n\|_2 + Mh^2/2.$$

从 $\mathbf{e}_0 = \mathbf{0}$ 展开, $\|\mathbf{e}_n\|_2 \leq (Mh^2/2) \sum_{j=0}^{n-1} (1+Lh)^j$. $L > 0$ 时求几何和, 并用 $(1+Lh)^n \leq e^{Ln h} \leq e^{LT}$, 即得所述界; $L = 0$ 时直接使用 $nh \leq T$. ■

这也是离散 Grönwall 估计的一个具体推导。局部 $O(h^2)$ 经约 T/h 步累计成为全局 $O(h)$, 而动力学决定这些误差随后放大多少。更一般地, 若数值映射的 Lipschitz 常数不超过 L_h 、沿精确轨迹的局部误差不超过 τ_h , 则

$$\|\mathbf{e}_{n+1}\| \leq L_h \|\mathbf{e}_n\| + \tau_h, \quad \|\mathbf{e}_n\| \leq L_h^n \|\mathbf{e}_0\| + \tau_h \sum_{j=0}^{n-1} L_h^j.$$

有限精度中的舍入误差也会通过同一传播机制进入后续状态。不断减小步长能减少截断误差, 却增加运算次数, 未必无限改善最后精度。

示例 13.9 连续稳定与数值稳定不是一回事 对 $\dot{x} = -\lambda x + u$, 其中 $\lambda > 0$ 且 u 恒定, 精确一步为

$$x(t+h) = e^{-\lambda h} x(t) + \frac{1-e^{-\lambda h}}{\lambda} u.$$

Euler 一步为 $\hat{x}_{n+1} = (1-\lambda h)\hat{x}_n + hu$ 。连续齐次系统始终指数衰减, Euler 齐次递推却只有 $|1-\lambda h| < 1$, 即 $0 < h < 2/\lambda$ 时才衰减。

当 $1 < h\lambda < 2$, 数值状态交替变号但幅值缩小; 当 $h\lambda > 2$, 它交替增长。若同一系统包含衰减很快与变化很慢的方向, 显式方法可能为压住快方向而被迫采用远小于慢变化尺度的步长, 这就是刚性带来的主要计算困难。提高阶数不自动解除稳定域限制; 此处稳定域指使齐次数值解衰减的参数范围。隐式方法改用包含下一状态的信息。例如隐式 Euler (implicit Euler) 满足

$$\hat{\mathbf{x}}_{n+1} = \hat{\mathbf{x}}_n + hf(t_{n+1}, \hat{\mathbf{x}}_{n+1}).$$

未知的下一状态同时出现在等号两侧, 因而每步都需解方程。对相同的齐次泄漏模型, 它给出 $\hat{x}_{n+1} = \hat{x}_n/(1+h\lambda)$, 当 $h\lambda > 0$ 时放大因子的模始终小于 1。这说明改变更新规则可以扩大该例的稳定域, 代价是每步求解; 衰减得到保证也不等于任意大步长都能准确刻画轨迹。

13.2.4.2 线性状态下的精确离散

一般方法近似一步流, 线性方程则可在规定的输入模型下直接积分。设 $[t_n, t_n+h]$ 内 $\mathbf{u}(t) = \mathbf{u}_n$, 对式 (13.13) 取一个区间, 得到

$$\mathbf{x}_{n+1} = \mathbf{A}_h \mathbf{x}_n + \mathbf{B}_h \mathbf{u}_n, \quad (13.19)$$

$$\mathbf{A}_h = e^{h\mathbf{A}}, \quad \mathbf{B}_h = \int_0^h e^{(h-s)\mathbf{A}} \mathbf{B} ds. \quad (13.20)$$




图 13.1 教学方程 $\dot{x} = -x$ 、 $x(0) = 1$ 的精确解与 Euler 近似。蓝色实线为精确解，红色方点为数值状态；左图 $h = 0.5$ 衰减，右图 $h = 2.2$ 交替增长。两图采用相同坐标范围，连线只连接相邻数值状态。右图的发散来自步长，并非原连续系统不稳定。

这称为零阶保持离散化。精确性针对区间内保持不变的输入，不表示真实输入在区间内任意变化时也精确。若 A 可逆， $B_h = A^{-1}(e^{hA} - I)B$ ； A 奇异时继续使用积分形式，不人为引入不存在的逆。输入保持误差与计算矩阵指数的数值误差仍可能存在，只是没有 Euler 式的时间截断误差。

13.2.4.3 保守状态下的几何离散

对于可分 Hamilton 量，势能子系统保持位置、只改变动量；动能子系统保持动量、只改变位置。两者各自可精确求解，因而可用对称分裂组成一步蛙跳：

$$\mathbf{p}_{n+1/2} = \mathbf{p}_n - \frac{h}{2} \nabla U(\mathbf{q}_n), \quad (13.21)$$

$$\mathbf{q}_{n+1} = \mathbf{q}_n + h \mathbf{M}^{-1} \mathbf{p}_{n+1/2}, \quad (13.22)$$

$$\mathbf{p}_{n+1} = \mathbf{p}_{n+1/2} - \frac{h}{2} \nabla U(\mathbf{q}_{n+1}). \quad (13.23)$$

它是“动量半步、位置整步、动量半步”，不是把两条方程各做一次独立 Euler 更新。令 $S_U^c(\mathbf{q}, \mathbf{p}) = (\mathbf{q}, \mathbf{p} - c \nabla U(\mathbf{q}))$ 、 $S_K^h(\mathbf{q}, \mathbf{p}) = (\mathbf{q} + h \mathbf{M}^{-1} \mathbf{p}, \mathbf{p})$ 。若 $U \in C^2$ ，相应 Jacobian 为

$$G_U = \begin{bmatrix} I & 0 \\ -c \nabla^2 U & I \end{bmatrix}, \quad G_K = \begin{bmatrix} I & h \mathbf{M}^{-1} \\ 0 & I \end{bmatrix}.$$

三角结构使二者行列式均为 1； $\nabla^2 U$ 和 $\mathbf{M}^{-1}$ 的对称性又给出 $G_U^\top J G_U = J$ 及 $G_K^\top J G_K = J$ 。故复合 $\Psi_h = S_U^{h/2} \circ S_K^h \circ S_U^{h/2}$ 保持体积且为辛映射。

每个子步换成负步长便是其逆，三步的对称排列使 $\Psi_h^{-1} = \Psi_{-h}$ 。若 $R(\mathbf{q}, \mathbf{p}) = (\mathbf{q}, -\mathbf{p})$ 是动量翻转，则还有

$$R \circ \Psi_h \circ R = \Psi_{-h} = \Psi_h^{-1}.$$

因此这里的时间反演关系涉及动量翻转。把同一个映射连续应用两次便回到原态，即 $\Psi_h \circ \Psi_h = \text{id}$ ，才称该映射为对合 (involution)；上面的逆映射关系不要求 Ψ_h 满足这个条件。在足够光滑和固定有限时域下，蛙跳具有二阶全局精度。合适光滑性、轨迹有界及小步长条件下的修正能量分析解释了常见的长时间有界能量振荡；辛性本身不保证原 Hamilton 量每步完全相同。

示例 13.10 谐振子的精确与数值轨道 取 $U(q) = q^2/2, M = 1$ ，精确解沿 $q^2 + p^2$ 的等值圆运动。蛙跳一步为

$$\begin{bmatrix} q_{n+1} \\ p_{n+1} \end{bmatrix} = \begin{bmatrix} 1 - h^2/2 & h \\ -h + h^3/4 & 1 - h^2/2 \end{bmatrix} \begin{bmatrix} q_n \\ p_n \end{bmatrix}.$$

更新矩阵的行列式为 1、迹为 $2 - h^2$ 。当 $0 < h < 2$ 时，其特征值是不同的单位模共轭数，并精确保持 $(1 - h^2/4)q_n^2 + p_n^2$ ；这是一族椭圆，不是原来的能量圆。例如从 $(1, 0)$ 出发取 $h = 1$ ，一步得到 $(1/2, -3/4)$ ，原能量从 $1/2$ 变成 $13/32$ ，却仍保持上述修正二次型。 $h > 2$ 时出现模大于 1 的特征值， $h = 2$ 时还有退化导致的增长方向。

所以可逆、辛、体积保持与数值稳定分别需要检查。将这类轨迹用于随机采样时，能量误差还需接受校正，不能把几何积分器直接当作精确采样器。

13.2.5 仿射更新下的轨迹并行计算

离散化选择数值规则，并行计算则重新安排同一规则的求值。对仿射递推

$$\mathbf{x}_{t+1} = \mathbf{A}_t \mathbf{x}_t + \mathbf{b}_t, \quad (13.24)$$

用二元组 $g_t = (\mathbf{A}_t, \mathbf{b}_t)$ 表示一步，定义较晚更新接在较早更新之后的复合为

$$(\mathbf{A}_2, \mathbf{b}_2) \circ (\mathbf{A}_1, \mathbf{b}_1) = (\mathbf{A}_2 \mathbf{A}_1, \mathbf{A}_2 \mathbf{b}_1 + \mathbf{b}_2). \quad (13.25)$$

复合结果仍是同维度仿射映射，这是能够紧凑表示整段更新的关键。三步直接核对得

$$\begin{aligned} g_3 \circ (g_2 \circ g_1) &= (\mathbf{A}_3 \mathbf{A}_2 \mathbf{A}_1, \mathbf{A}_3 \mathbf{A}_2 \mathbf{b}_1 + \mathbf{A}_3 \mathbf{b}_2 + \mathbf{b}_3) \\ &= (g_3 \circ g_2) \circ g_1. \end{aligned}$$

结合律允许用前缀扫描 (prefix scan) 同时求全部 $g_{t-1} \circ \cdots \circ g_0$ 。把更新按时间次序放在一棵平衡二叉树的叶子上, 上行阶段合并相邻块, 每个内部节点保存自己整段的总复合。这个阶段只得到块的总映射, 全部中间状态还需要一次下传。

下传时, 节点接收其区间之前已经完成的累计映射 p 。左孩子继续接收 p ; 若左块的总映射是 L , 右孩子就接收 $L \circ p$ 。根节点接收恒等映射 $(I, \mathbf{0})$ 。例如四步 g_0, g_1, g_2, g_3 时, 左半块的总映射为 $L = g_1 \circ g_0$, 四个叶子接收到的前缀分别是

$$\begin{aligned} p_0 &= \text{id}, & p_1 &= g_0, \\ p_2 &= L, & p_3 &= g_2 \circ L. \end{aligned}$$

叶子 i 再形成 $g_i \circ p_i$ 并作用于 $\mathbf{x}_0$, 便得到 $\mathbf{x}_{i+1}$ 。右块始终接在左块之后, 所以这套下传规则也适用于不交换的复合。

总工作量统计所有节点执行的合并次数, 计算深度统计最长依赖链上的合并次数。 T 步形成的平衡树有 $O(T)$ 个节点、 $O(\log T)$ 层, 上下两阶段在每个节点只做常数次合并, 同层互不依赖的节点可同时计算。因此把一次固定维度合并视为一个操作时, 总工作量为 $O(T)$, 深度为 $O(\log T)$ 。矩阵维度增长时, 合并的实际算术成本仍需另算。

扫描保留时间次序。若 $g_1(\mathbf{x}) = \text{diag}(2, 1)\mathbf{x}$ 、 $g_2(\mathbf{x}) = \mathbf{x} + (1, 0)^\top$, 则

$$(g_2 \circ g_1)(\mathbf{0}) = (1, 0)^\top, \quad (g_1 \circ g_2)(\mathbf{0}) = (2, 0)^\top.$$

这两个结果说明结合律不能换成交换律。浮点运算下, 改变括号也可能改变舍入结果, 尤其是长乘积或条件数较大的传播; 并行实现应按误差容忍验证, 而不是要求逐位相同。若 $\mathbf{A}_t, \mathbf{b}_t$ 只依赖事先给定的输入, 仍可预先组成仿射扫描; 若依赖尚未算出的状态, 或复合后不再有固定大小的封闭表示, 就需要另行分析, 不能直接套用。

13.3 状态轨迹的极限与稳定

得到轨迹以后, 还要回答两个长期问题: 轨迹最终接近哪里, 初值受到小扰动后, 轨迹又会偏离多少。二者需要分别判断。所有轨迹最终趋于平衡点, 也可能先放大初值误差再逐渐减小; 保持能量的轨迹则可能始终沿闭合曲线运动。下面先明确“接近”与“偏离”的含义, 再用线性或非线性结构判断它们。数值离散改变了更新规则, 因此数值递推的稳定性还需要单独分析。

13.3.1 状态轨迹的极限与稳定性质

定义 13.11 平衡点与稳定性 考虑局部 Lipschitz 自治方程 $\dot{\mathbf{x}} = \mathbf{f}(\mathbf{x})$ 。满足 $\mathbf{f}(\mathbf{x}^*) = \mathbf{0}$ 的状态称为平衡点。以下性质均要求所涉及初值的解对全部 $t \geq 0$ 存在。

平衡点在 Lyapunov 意义下稳定, 是指对每个 $\varepsilon > 0$, 存在 $\delta > 0$, 使 $\|\mathbf{x}(0) - \mathbf{x}^*\| < \delta$ 蕴含 $\|\mathbf{x}(t) - \mathbf{x}^*\| < \varepsilon$ 对全部 $t \geq 0$ 成立。它具有局部吸引力, 是指存在 $r > 0$, 使所有 $\|\mathbf{x}(0) - \mathbf{x}^*\| < r$ 的解都趋于 $\mathbf{x}^*$ 。同时稳定且有局部吸引力称为渐近稳定。若存在 $r, C, \alpha > 0$, 对上述 r 邻域内全部初值和 $t \geq 0$ 都有

$$\|\mathbf{x}(t) - \mathbf{x}^*\|_2 \leq C e^{-\alpha t} \|\mathbf{x}(0) - \mathbf{x}^*\|_2,$$

则称为局部指数稳定。若同一估计对全部初值成立, 则称为全局指数稳定。

离散时间把 $t \geq 0$ 换成非负整数, 平衡条件换成 $F(\mathbf{x}^*) = \mathbf{x}^*$, 指数因子可写成 q^t , 其中 $0 < q < 1$ 。“最终接近”与“始终不远离”分别对应吸引与稳定; 不能只展示一条收敛轨迹, 便省去邻域内全部初值的量词。指数条件还要求 C, α 在整个邻域统一。

方程与原点	小初值始终小	轨迹趋于原点	统一指数衰减
$\dot{x} = 0$	是, 状态保持初值	否, 非零初值不动	否
$\dot{x} = -x^3$	是, $ x(t) $ 不增	是, 代数衰减	否
$\dot{x} = -x$	是	是	是, $ x(t) = e^{-t} x(0) $

表 13.1 零输入下原点的稳定性质。第二行的解为 $x(t) = x(0)/\sqrt{1 + 2x(0)^2 t}$, 它回到原点但不具有统一指数速度。三种方程均有全局解, 比较不涉及数值离散。

有些轨迹不趋于一点, 而是长期绕着一个集合运动。对此需要集合版本的描述。

定义 13.12 不变集合与轨迹极限集 设 Φ_t 是局部 Lipschitz 自治方程的流, 并要求所述集合上的解正向全局存在。若 $\Phi_t(\Omega) \subseteq \Omega$ 对全部 $t \geq 0$ 成立, 则 Ω 为正向不变集。若 $\Phi_t(M) = M$ 对全部 $t \geq 0$ 成立, 则 M 为不变集; 这还要求集合内每一点有任意长时间以前的集合内前像, 等价于每点都位于始终留在集合内的完整轨迹上。对正向有界轨迹, 定义其 ω 极限集为

$$\omega(\mathbf{x}_0) = \{\mathbf{z} : \text{存在 } t_j \rightarrow \infty \text{ 使 } \mathbf{x}(t_j) \rightarrow \mathbf{z}\}.$$

正向不变集限制一批初值的全部未来，极限集则记录一条轨迹在越来越晚的时刻反复靠近的状态。趋于集合指到该集合的距离趋零，不要求在集合内部停止运动。

为了不逐条求解轨迹，常寻找一个能度量离开平衡点程度的标量。以原点为平衡， $V \in C^1(D)$ 若满足 $V(\mathbf{0}) = 0$ 且非零点上 $V > 0$ ，称为正定的 Lyapunov 候选。这些条件让原点成为 V 的严格最小点。称它为“候选”，是因为我们还需要计算状态演化时 V 是否会减小，才能用它判断稳定性。

定义 13.13 Lyapunov 函数 对 $\dot{\mathbf{x}} = \mathbf{f}(\mathbf{x})$ ，若上述正定候选还满足 $\dot{V}(\mathbf{x}) := \nabla V(\mathbf{x})^\top \mathbf{f}(\mathbf{x}) \leq 0$ ，则称其为该邻域内的 Lyapunov 函数；若非零点处严格小于零，则称为严格 Lyapunov 函数。

它不必等于物理能量。离散方程相应检查 $V(F(\mathbf{x})) - V(\mathbf{x})$ 。正定性使“小能量”确实限制所有状态方向，非增性才保证轨迹不能穿越更高的能量边界。下面的线性与非线性判据共同使用这两项。

13.3.2 线性演化下的轨迹稳定性

13.3.2.1 长期演化的谱判据

离散齐次系统为

$$\mathbf{x}_{t+1} = \mathbf{A}\mathbf{x}_t, \quad \mathbf{x}_t = \mathbf{A}^t \mathbf{x}_0. \quad (13.26)$$

矩阵的幂、Jordan 分解与指数已在第 6 章建立。这里用它们把长期轨迹问题化成谱的位置。

定理 13.14 离散线性系统的渐近稳定性 式 (13.26) 的原点全局渐近稳定，当且仅当 $\rho(\mathbf{A}) = \max_{\lambda \in \text{spec}(\mathbf{A})} |\lambda| < 1$ 。在此条件下，原点实际上全局指数稳定。

证明. 在复数域写 $\mathbf{A} = \mathbf{V}\mathbf{J}\mathbf{V}^{-1}$ 。大小为 r 的 Jordan 块 $\mathbf{J}_\lambda = \lambda\mathbf{I} + \mathbf{N}$ 满足

$$\mathbf{J}_\lambda^t = \sum_{j=0}^{\min(t, r-1)} \binom{t}{j} \lambda^{t-j} \mathbf{N}^j.$$

$\lambda = 0$ 的块在有限步后为零； $0 < |\lambda| < 1$ 时，多项式因子被几何衰减压过。取 $\rho(\mathbf{A}) < q < 1$ ，全部有限个块可统一控制为 Cq^t ，乘回换基矩阵得 $\|\mathbf{A}^t\| \leq C'q^t$ 。它既给出趋零，也给出稳定性所需的统一有界增益。反之，若存在 $|\lambda| \geq 1$ ，沿其特征向量的复轨迹不趋零；分解成实部与虚部，至少一条实轨迹不趋零。单位模特征值的非平凡 Jordan 块还可能多项式增长。故渐近稳定要求全部特征值严格在单位圆内。 ■

定理 13.15 连续线性系统的指数稳定性 系统 $\dot{\mathbf{x}} = \mathbf{A}\mathbf{x}$ 的原点全局指数稳定, 当且仅当 $\mathbf{A}$ 的全部特征值实部严格为负。这样的矩阵称为 Hurwitz 矩阵。

证明. 对 Jordan 块, $\mathbf{e}^{t(\lambda\mathbf{I}+\mathbf{N})} = \mathbf{e}^{\lambda t} \sum_{j=0}^{r-1} t^j \mathbf{N}^j / j!$ 。若全部实部为负, 取 $0 < \alpha < -\max_{\lambda} \operatorname{Re} \lambda$, 有限次多项式乘指数可统一控制为 $C\mathbf{e}^{-\alpha t}$ 。乘回换基矩阵就得到 $\|\mathbf{e}^{t\mathbf{A}}\| \leq C'\mathbf{e}^{-\alpha t}$ 。若某个特征值实部非负, 则对应实不变子空间中存在增长、常值或不衰减振荡的轨迹, 不可能满足该指数界。非平凡 Jordan 块不会消除这种障碍。 ■

连续系统检查左半平面, 离散系统检查单位圆。边界上的谱需另查 Jordan 结构: 可能稳定而不吸引, 也可能增长, 不能把严格不等号改成非严格不等号。

特征值的位置告诉我们状态在长期是否衰减。若还希望逐时刻判断状态有没有偏离平衡, 可以构造一个二次型, 并检查它是否沿轨迹下降。取 $V(\mathbf{x}) = \mathbf{x}^\top \mathbf{P}\mathbf{x}$, 其中 $\mathbf{P} > \mathbf{0}$, 则

$$\dot{V} = \mathbf{x}^\top (\mathbf{A}^\top \mathbf{P} + \mathbf{P}\mathbf{A}) \mathbf{x}. \quad (13.27)$$

定理 13.16 线性 Lyapunov 方程 $\mathbf{A}$ 为 Hurwitz 矩阵, 当且仅当对每个 $\mathbf{Q} > \mathbf{0}$, 存在唯一 $\mathbf{P} > \mathbf{0}$ 满足

$$\mathbf{A}^\top \mathbf{P} + \mathbf{P}\mathbf{A} = -\mathbf{Q}. \quad (13.28)$$

证明. 若 $\mathbf{A}$ 为 Hurwitz 矩阵, 定义 $\mathbf{P} = \int_0^\infty \mathbf{e}^{t\mathbf{A}^\top} \mathbf{Q} \mathbf{e}^{t\mathbf{A}} dt$ 。指数稳定保证积分收敛。任意非零 $\mathbf{x}$ 对应的被积二次型非负, 且在 $t=0$ 严格为正, 所以 $\mathbf{P} > \mathbf{0}$ 。对被积矩阵求导并积分, 得

$$\mathbf{A}^\top \mathbf{P} + \mathbf{P}\mathbf{A} = [\mathbf{e}^{t\mathbf{A}^\top} \mathbf{Q} \mathbf{e}^{t\mathbf{A}}]_0^\infty = -\mathbf{Q}.$$

两解之差 $\mathbf{D}$ 满足 $\mathbf{A}^\top \mathbf{D} + \mathbf{D}\mathbf{A} = \mathbf{0}$, 故 $\mathbf{e}^{t\mathbf{A}^\top} \mathbf{D} \mathbf{e}^{t\mathbf{A}}$ 恒为 $\mathbf{D}$; 令 $t \rightarrow \infty$ 得 $\mathbf{D} = \mathbf{0}$ 。

反之, 若存在正定的 $\mathbf{P}, \mathbf{Q}$ 满足方程, 记 $p_- = \lambda_{\min}(\mathbf{P})$ 、 $p_+ = \lambda_{\max}(\mathbf{P})$ 、 $q_- = \lambda_{\min}(\mathbf{Q})$ 。则 $p_- \|\mathbf{x}\|_2^2 \leq V \leq p_+ \|\mathbf{x}\|_2^2$, 且 $\dot{V} = -\mathbf{x}^\top \mathbf{Q} \mathbf{x} \leq -(q_-/p_+)V$ 。乘以积分因子得到

$$\|\mathbf{x}(t)\|_2 \leq \sqrt{p_+/p_-} \mathbf{e}^{-q_- t/(2p_+)} \|\mathbf{x}(0)\|_2.$$

这直接证明指数稳定; 由已证谱判据, $\mathbf{A}$ 为 Hurwitz 矩阵。 ■

反向证明只用二次型上下界与积分估计，不依赖尚未建立的非线性判据。

定理 13.17 离散时间 Lyapunov 方程 $\rho(A) < 1$ ，当且仅当对每个 $Q > 0$ ，存在唯一 $P > 0$ 满足 $A^\top P A - P = -Q$ 。

证明. 正向取 $P = \sum_{j=0}^{\infty} (A^\top)^j Q A^j$ 。上述离散指数界使级数绝对收敛；首项正定、其余项半正定，故 P 正定。左乘 $A^\top$ 、右乘 A 后相减即得方程。两解之差满足 $D = (A^\top)^t D A^t$ ，令 $t \rightarrow \infty$ 得唯一性。反向用 $V(x) = x^\top P x$ ，有

$$V(Ax) - V(x) = -x^\top Q x < 0 \quad (x \neq 0).$$

比值 $V(Ax)/V(x)$ 在单位球面上连续且严格小于 1，因紧性有统一上界 $c < 1$ ，且 $c \geq 0$ 。于是 $V(x_t) \leq c^t V(x_0)$ ($c = 0$ 时一步后即为零)。二次型界给出指数稳定，再由谱判据得到 $\rho(A) < 1$ 。 ■

线性系统因此总能为稳定动力学找到某个二次能量，但这个能量一般不是欧氏范数平方。下面用一个例子说明：状态最终趋零，为什么欧氏范数仍可能在中途增大。

13.3.2.2 有限时间的瞬态放大

取

$$A = \begin{bmatrix} 1/2 & K \\ 0 & 1/2 \end{bmatrix}, \quad K > 0.$$

无论 K 多大，谱半径均为 $1/2$ ，而

$$A^t = \begin{bmatrix} 2^{-t} & tK 2^{-(t-1)} \\ 0 & 2^{-t} \end{bmatrix}.$$

从 $x_0 = (0, 1)^\top$ 出发，第一步即为 $(K, 1/2)^\top$ ，欧氏范数可以大幅增长；之后 $t2^{-t} \rightarrow 0$ 才使状态趋零。这里放大来自第二坐标向第一坐标的耦合，没有任何输入或数值误差。

$K \neq 0$ 时， $A^\top A \neq AA^\top$ ，矩阵非正规。本例只有一个独立特征向量，幂零耦合产生 $t2^{-t}$ 项。另一些非正规矩阵可以对角化，但特征向量几乎共线：初态在不同特征方向上的分量可能相互抵消，随后各分量以不同速度衰减，抵消减弱，状态范数就可能暂时增大。有限时间增益 $\|A^t\|$ 、伪谱与合适的 Lyapunov 范数描述了谱半径以外的信息。所以谱判据保证长期衰减，却不保证欧氏范数每步都减小，也不保证中间状态始终满足任务的温度、幅度等限制。




图 13.2 同谱系统的不同瞬态。初值均为 $(0, 1)^T$ ，蓝色圆点取 $K = 0$ ，红色方点取 $K = 4$ ，谱半径均为 $1/2$ 。后者前两步范数约为 4.03、4.01，随后才趋零；灰线为初始范数 1。长期衰减不等于每一步都收缩。

13.3.3 非线性演化下的轨迹稳定性

13.3.3.1 平衡邻域内的稳定判据

非线性系统一般无法通过一个固定矩阵构造全局二次能量，因而需要寻找候选函数。它可以来自物理能量、误差平方或模型特有的守恒与耗散关系。找到候选以后，仍须检查正定性、沿轨迹导数以及适用区域²。

² H. K. Khalil, *Nonlinear Systems*, Prentice Hall, 2002, 3rd ed.

定理 13.18 连续时间 Lyapunov 判据 设原点为 $\dot{x} = f(x)$ 的平衡点， f 在其邻域内局部 Lipschitz。若该邻域存在 C^1 正定候选 V 且 $\dot{V} \leq 0$ ，则原点稳定；若非零点上 $\dot{V} < 0$ ，则原点局部渐近稳定。若这些条件在 $\mathbb{R}^d$ 上成立，且 $V(x) \rightarrow \infty$ 当 $\|x\| \rightarrow \infty$ ，则所有解正向全局存在；非增情形给出稳定性，严格下降情形给出全局渐近稳定性。

证明. 选足够小的 ε 使闭球位于适用邻域。球面上的连续正函数 V 有最小值 $c_\varepsilon > 0$ 。原点处连续性给出 $\delta < \varepsilon$ ，使 $\|x_0\| < \delta$ 时 $V(x_0) < c_\varepsilon$ 。轨迹若首次触及球面，必须达到至少 c_ε 的能量，与 $\dot{V} \leq 0$ 矛盾。更具体地，可选 x_0 所在的闭子水平集与闭球的交作为紧集 K ，且其能量水平严格低于球面最小值；轨迹不能穿出 K ，局部解可延拓到任意正时间。对全部足够小 ε 得到此结论即为稳定性。

若 $\dot{V}$ 在非零点严格为负，反设某条上述轨迹不趋零，则存在 $\varepsilon_0 > 0$ 及 $t_j \rightarrow \infty$ ，使 $\|x(t_j)\| \geq \varepsilon_0$ 。在紧集 K 上令 $M = \sup_K \|f\|$ 。非零轨迹下可取 $M > 0$ ；速度有界使每次达到该半径后至少在长度 $\varepsilon_0/(2M)$ 内保持 $\|x\| \geq \varepsilon_0/2$ 。函数 $-\dot{V}$ 在 $K \cap \{\|x\| \geq \varepsilon_0/2\}$ 上有严格正下界。选取互不相交的这些时间段，能量便减少无穷大量，与 $V \geq 0$ 矛盾。因而轨迹趋零。全

局且径向无界时，每个初值的子水平集都紧；同样的延拓与下降论证适用于任意初值，得到全局结论。 ■

径向无界性控制的是远处状态，不能用“在原点附近正定”代替。若还能找到 $c_1, c_2, c_3 > 0$ 使 $c_1\|\mathbf{x}\|^2 \leq V \leq c_2\|\mathbf{x}\|^2$ 、 $\dot{V} \leq -c_3\|\mathbf{x}\|^2$ ，则前述线性方程证明中的积分估计同样给出局部指数衰减。一般严格负导数未必有这种二次型比较，所以渐近稳定未必指数稳定。

13.3.3.2 不变区域内的极限集合

机械能常只在某些方向上直接耗散，导致 $\dot{V} = 0$ 的集合远大于平衡点。这时应问：轨迹能否一直留在这个集合中？LaSalle 原理把这个问题转成极限集合判据。

定理 13.19 LaSalle 不变性原理 设自治向量场 $\mathbf{f}$ 局部 Lipschitz, Ω 紧且正向不变, V 在包含 Ω 的开邻域上为 C^1 , 并有 $\dot{V} \leq 0$ 。令 $E = \{\mathbf{x} \in \Omega : \dot{V}(\mathbf{x}) = 0\}$, M 为 E 中最大不变集, 则从 Ω 出发的每条轨迹满足 $\text{dist}(\mathbf{x}(t), M) \rightarrow 0$ 。

证明. 紧性排除有限时间逃逸, 也使 $\omega(\mathbf{x}_0)$ 非空且紧。沿轨迹的 V 单调不减且有下界, 故趋于 v_∞ 。对极限点 $\mathbf{z} = \lim_j \mathbf{x}(t_j)$, 连续性给出 $V(\mathbf{z}) = v_\infty$ 。

对固定 $s \geq 0$, 流的初值连续性使 $\mathbf{x}(t_j + s) \rightarrow \Phi_s(\mathbf{z})$, 故 $\Phi_s(\omega(\mathbf{x}_0)) \subseteq \omega(\mathbf{x}_0)$ 。反过来, 充分大的 j 有 $t_j > s$ 。紧性允许从 $\mathbf{x}(t_j - s)$ 取收敛子列, 其极限 $\mathbf{w}$ 属于 $\omega(\mathbf{x}_0)$, 且 $\Phi_s(\mathbf{w}) = \mathbf{z}$ 。因此 $\Phi_s(\omega(\mathbf{x}_0)) = \omega(\mathbf{x}_0)$, 这里得到的是完整不变性, 而非仅正向不变性。

V 在极限集上恒为 v_∞ , 从其中任一点出发的轨迹仍在该集合, 所以沿轨迹导数为零。于是 $\omega(\mathbf{x}_0)$ 是 E 内的不变集, 必包含于 M 。若到 M 的距离不趋零, 就有 $\varepsilon > 0$ 及 $t_j \rightarrow \infty$ 使距离至少为 ε 。紧性再给出收敛子列, 其极限属于 $\omega(\mathbf{x}_0) \subseteq M$, 与此距离下界矛盾。 ■

示例 13.20 阻尼振子的零导数集合 对 $\dot{q} = p, \dot{p} = -q - cp$, 其中 $c > 0$, 取 $V = (q^2 + p^2)/2$, 则 $\dot{V} = qp + p(-q - cp) = -cp^2 \leq 0$ 。零导数集合为 $p = 0$; 但其上 $q \neq 0$ 的点满足 $\dot{p} = -q \neq 0$, 马上离开该直线。因此零导数集合中最大不变集只有原点。每个能量子水平集均紧且正向不变, LaSalle 原理遂给出所有轨迹趋于原点。

能量非增先限制活动区域, 动力学再排除不能持续停留的零导数点。把整个 E 直接称为“最终状态”, 会丢掉 LaSalle 论证中最关键的一步。




图 13.3 阻尼振子 $\dot{q} = p, \dot{p} = -q - p$ 从 $(1,0)$ 出发的精确轨迹。黄色轨迹覆盖 $t = 0$ 至 12，箭头指示时间；灰色虚线为 $\dot{V} = 0$ 的直线 $p = 0$ ，浅灰圆为能量参考等值线。起点虽在零导数集合上，初始速度 $(0, -1)$ 却将它带离该集合；能一直留在其中的完整轨迹只有原点。

13.3.4 初值与输入扰动下的轨迹稳定性

前述原点判据通常对应零输入，或把恒定输入下的平衡平移到原点。温度例的恒定 $u_t = 0.4$ 对应平衡 2，误差 $e_t = x_t - 2$ 才满足 $e_{t+1} = 0.8e_t$ 。不能因为误差趋零，就说实际温度趋于环境温度。

对连续方程，若 $\mathbf{f}$ 关于状态具有 Lipschitz 常数 L ，同一输入下两条解满足

$$\|\mathbf{x}(t) - \tilde{\mathbf{x}}(t)\| \leq e^{L(t-t_0)} \|\mathbf{x}_0 - \tilde{\mathbf{x}}_0\|.$$

这是由积分方程与引理 13.4 得到的有限时间连续依赖，在 $L > 0$ 时没有声称衰减。若输入也不同， $\mathbf{f}$ 关于输入的 Lipschitz 常数为 L_u ，并且比较模型沿第二条轨迹还有大小至多 $r(s)$ 的向量场误差，则同一引理给出

$$\|\mathbf{x}(t) - \tilde{\mathbf{x}}(t)\| \leq e^{L(t-t_0)} \|\mathbf{x}_0 - \tilde{\mathbf{x}}_0\| + \int_{t_0}^t e^{L(t-s)} (L_u \|\mathbf{u}(s) - \tilde{\mathbf{u}}(s)\| + r(s)) ds.$$

初态误差、输入误差、模型误差因此有不同来源，却都要经过后续动态传播。

对指数稳定线性系统, 若 $\|e^{tA}\| \leq Me^{-\alpha t}$, 常数变易公式给出更强的界:

$$\|\mathbf{x}(t)\| \leq Me^{-\alpha(t-t_0)}\|\mathbf{x}_0\| + M\|\mathbf{B}\| \int_{t_0}^t e^{-\alpha(t-s)}\|\mathbf{u}(s)\| ds.$$

若 $\|\mathbf{u}(s)\| \leq U$, 第二项至多 $(M\|\mathbf{B}\|U/\alpha)(1 - e^{-\alpha(t-t_0)})$ 。有界输入产生有界状态, 但持续输入通常留下非零稳态。离散温度例若输入固定偏多 δu , 稳态偏差就是 $\delta u/(1 - 0.8) = 5\delta u$ 。稳定系统会逐渐减弱初值的影响, 但持续施加的输入偏差仍会留下稳态误差。

13.4 随机状态与随机轨迹

给定相同初温与加热量, 开门、风速等未显式建模的作用仍可能改变真实温度。把这些作用表示成过程噪声后, 更新公式不再只产生一条确定轨迹, 而是把噪声的联合规律转换为状态的联合规律。本节先研究噪声怎样产生状态轨迹; 利用传感器读数更新状态概率的问题留到后文。离散更新可以直接逐步随机生成; 连续时间必须先说明随机增量怎样累计。

13.4.1 随机状态的离散演化

13.4.1.1 随机递推与状态转移

在同一概率空间上给定初始状态、输入及背景随机量, 写

$$\mathbf{x}_{t+1} = F_t(\mathbf{x}_t, \mathbf{u}_t, \boldsymbol{\varepsilon}_{t+1}).$$

若 $\boldsymbol{\varepsilon}_{t+1}$ 独立于已有状态历史, 分布为 ν_{t+1} , 且 F_t 可测, 并将本节的输入 $(\mathbf{u}_t)$ 固定为预先给定的确定序列, 则由更新映射得到转移核

$$K_t(\mathbf{x}, A) = \int \mathbb{I}\{F_t(\mathbf{x}, \mathbf{u}_t, \mathbf{e}) \in A\} \nu_{t+1}(d\mathbf{e}).$$

对每个 $\mathbf{x}$ 它是概率分布, 对每个可测 A 它关于 $\mathbf{x}$ 可测, 符合定义 10.20。独立性使 $\mathbb{P}(\mathbf{x}_{t+1} \in A \mid \mathbf{x}_{0:t}) = K_t(\mathbf{x}_t, A)$, 这才得到当前状态的 Markov 性质。给定 $\pi_0 = \mathcal{L}(\mathbf{x}_0)$, 整条有限轨迹满足

$$\mathbb{P}(\mathbf{x}_{0:T} \in d\mathbf{z}_{0:T}) = \pi_0(d\mathbf{z}_0) \prod_{t=0}^{T-1} K_t(\mathbf{z}_t, d\mathbf{z}_{t+1}),$$

其中乘积表示逐次核积分。它同时规定跨时刻依赖, 而不只是各个时刻的边缘分布。若以后改用仅依赖当前状态的可测反馈 $\mathbf{u}_t = \pi_t(\mathbf{x}_t)$, 把 $\pi_t(\mathbf{x})$ 代入核即可。若输入还依赖更早的状态或带噪观测, 仅有新噪声独立通常不足以使 $\mathbf{x}_t$ 本身为 Markov 状态; 须保留相应历史或扩充状态。这一区别将在第 14 章“策略的实现与轨迹控制”中用于规定可实施策略。

常用的线性加性模型为

$$\mathbf{x}_{t+1} = \mathbf{A}_t \mathbf{x}_t + \mathbf{B}_t \mathbf{u}_t + \mathbf{w}_{t+1}. \quad (13.29)$$

若 $\mathbf{w}_{t+1} \sim \mathcal{N}(\mathbf{0}, \mathbf{Q}_{t+1})$ 且独立于初态与其他过程噪声, $K_t(\mathbf{x}, \cdot) = \mathcal{N}(\mathbf{A}_t \mathbf{x} + \mathbf{B}_t \mathbf{u}_t, \mathbf{Q}_{t+1})$ 。即便 $\mathbf{Q}_{t+1}$ 奇异, 它仍是合法概率核, 只是不一定有全维 Lebesgue 密度。

相关噪声需要重新检查条件结构。例如 $x_{t+1} = ax_t + w_{t+1}$, 而 $w_{t+1} = \rho w_t + \varepsilon_{t+1}$, 其中新 ε 独立。代入 $w_t = x_t - ax_{t-1}$ 得 $x_{t+1} = (a + \rho)x_t - \rho ax_{t-1} + \varepsilon_{t+1}$ 。此时下一状态一般还依赖 x_{t-1} , 只知道 x_t 不能确定下一状态的条件分布。若同时记录 (x_t, w_t) , 就能计算下一步的状态与噪声; 也可以继续按更长历史写出条件分布。因此, 判断 Markov 性质时, 要检查当前记录的信息是否足够, 不能仅凭递推公式中出现了噪声作出判断。

温度模型现在恢复为

$$x_{t+1} = 0.8x_t + u_t + w_{t+1}, \quad w_{t+1} \sim \mathcal{N}(0, 0.04).$$

取各 w_t 相互独立且独立于初态。若 $x_0 = 0, u_t = 0.4$, 则 $\mathbb{E}x_t = 2(1 - 0.8^t)$, 过程方差为 $0.04 \sum_{j=0}^{t-1} 0.8^{2j}$ 。平均轨迹仍与无噪模型相同, 一条实际轨迹却会在其附近波动。图 13.4 再叠加 $y_t = x_t + v_t$ 、 $v_t \sim \mathcal{N}(0, 0.09)$ 的独立读数噪声, 先展示状态和读数怎样生成; 怎样由读数推断状态留到观测部分。




图 13.4 同一温度模型的两个对象。初态 $x_0 = 0$, 输入始终为 0.4; 无噪声轨迹趋于 2, 过程噪声改变真实状态, 独立观测噪声又把真实状态变成带噪读数。噪声方差分别为 0.04 和 0.09。图中带噪曲线是固定种子的教学模拟, 不是置信区间, 也没有把读数用于反向校正状态。

13.4.1.2 单时间尺度的随机逼近

有些递推状态不是房间温度，而是希望逐步求出的参数。设未知均值为 μ ，目标是解平均方程

$$h(\theta) = \mathbb{E}[Y - \theta] = \mu - \theta = 0. \quad (13.30)$$

每次只能得到一个含噪观测，无法直接算出 μ 。我们可以比较观测值与当前估计，再把估计向观测值移动一小步。只要平均而言更新把估计推向 μ ，就有可能通过重复更新找到平均方程的根。这种利用含噪更新求解平均方程的过程称为 **随机逼近**；后文还会讨论平均更新所形成的动力系统。算法轮次以括号上标标记，区别于物理状态的时间下标。一般形式为

$$\theta^{(t+1)} = \theta^{(t)} + \alpha_t [\bar{h}(\theta^{(t)}) + \xi_{t+1} + r_{t+1}], \quad (13.31)$$

其中 $\alpha_t > 0$ 是步长； $\bar{h}$ 是平均漂移，即在当前参数下希望实现的平均更新方向。 $\mathcal{F}_t$ 表示更新前已获得的信息，噪声满足 $\mathbb{E}[\xi_{t+1} | \mathcal{F}_t] = \mathbf{0}$ ，所以它是鞅差。 r_{t+1} 记录近似计算、截断或观测分布尚未达到平稳状态造成的偏差。相关的 Markov 观测一般不能直接写成这样的鞅差，后文将说明如何分解其累计误差。

均值问题的 Robbins–Monro 递推为

$$\theta^{(t+1)} = \theta^{(t)} + \alpha_t (Y_{t+1} - \theta^{(t)}). \quad (13.32)$$

观测高于当前估计就上移，低于估计就下移。若 $\mathbb{E}[Y_{t+1} | \mathcal{F}_t] = \mu$ ，条件平均方向恰为 $\mu - \theta^{(t)}$ 。取 $\alpha_t = 1/(t+1)$ 时，第一步完全采用 Y_1 ；归纳得 $\theta^{(t)} = t^{-1} \sum_{s=1}^t Y_s$ 。一般步长对应不等权的递推，所以随机逼近不限于样本平均。³

经典递减步长条件是

$$\sum_{t=0}^{\infty} \alpha_t = \infty, \quad \sum_{t=0}^{\infty} \alpha_t^2 < \infty. \quad (13.33)$$

前者保留无限的累计移动能力；若鞅差噪声的条件二阶矩有统一上界，后者就能控制累计的加权方差。具体地，对此前信息 $\mathcal{F}_t$ 和鞅差 ξ_{t+1} ，若 $\mathbb{E}[\xi_{t+1}^2 | \mathcal{F}_t] \leq \sigma^2$ ，则

$$\sum_{t=0}^{\infty} \alpha_t^2 \mathbb{E}[\xi_{t+1}^2 | \mathcal{F}_t] \leq \sigma^2 \sum_{t=0}^{\infty} \alpha_t^2 < \infty.$$

仅有每个时刻的方差有限还不够，因为这些方差可能随时间无界增长。 $\alpha_t = c/(t+t_0)^\gamma$ 在 $c, t_0 > 0$ 、 $1/2 < \gamma \leq 1$ 时满足两项。若步长和有限，初

³ H. Robbins, S. Monro, *A Stochastic Approximation Method In The Annals of Mathematical Statistics*, 1951, vol. 22, no. 3, pp. 400–407

始误差可能尚未消除就停止有效移动；若平方和无穷，上述噪声控制不再适用，但这本身也不是任意模型必然发散的断言。

固定步长则保留持续响应新数据的能力。对独立同分布、均值 μ 、方差 σ^2 的观测，确定初值及 $\alpha_t = \alpha \in (0, 1)$ 给出

$$e_{t+1} = (1 - \alpha)e_t + \alpha(Y_{t+1} - \mu), \quad \mathbb{E}e_t = (1 - \alpha)^t e_0.$$

由独立性，方差 $v_{t+1} = (1 - \alpha)^2 v_t + \alpha^2 \sigma^2$ ，因而

$$v_t = \frac{\alpha \sigma^2}{2 - \alpha} [1 - (1 - \alpha)^{2t}] \rightarrow \frac{\alpha \sigma^2}{2 - \alpha}.$$

初始偏差消失，随机波动却留下正的稳态方差。小步长降低此误差，也延缓对初值或目标变化的响应。这是固定均值模型的精确计算，不能替代一般非线性递推的稳定证明。




图 13.5 同一均值问题的重复实验均值与方差。取 $\theta^{(0)} = 0, \mu = 1, \sigma^2 = 1$ ，观测独立同分布；蓝实线为固定 $\alpha = 0.2$ ，红虚线为 $\alpha_t = 1/(t+1)$ 。固定步长方差趋于 $1/9$ ，样本平均方差为 $1/t$ 。曲线由解析式得到，不是一条样本轨迹。

前面的均值与方差描述了重复实验的平均结果。要进一步证明几乎每条样本路径的估计都趋于 μ ，需要控制噪声在所有更新中的累计作用。下面先用一个超鞅引理控制误差平方的极限，再排除极限仍大于零的情况。

引理 13.21 带可求和误差的非负超鞅 设 Z_t, A_t 为关于 $\mathcal{F}_t$ 的非负可积适应过程， $b_t \geq 0$ 为确定数，且 $\mathbb{E}[Z_{t+1} | \mathcal{F}_t] \leq Z_t - A_t + b_t$ 。若 $\sum_t b_t < \infty$ ，则 Z_t 几乎必然收敛到有限随机变量，且 $\sum_t A_t < \infty$ 几乎必然成立。

证明. 令 $r_t = \sum_{s=t}^{\infty} b_s$ 、 $U_t = Z_t + r_t$ 。因为 $r_t = b_t + r_{t+1}$ ，有 $\mathbb{E}[U_{t+1} | \mathcal{F}_t] \leq U_t - A_t$ 。 U_t 是非负超鞅，由非负超鞅收敛定理几乎必然收敛到有限值。取

期望并累加得到 $\mathbb{E} \sum_{t=0}^n A_t \leq \mathbb{E} U_0$ 。单调收敛给出 $\mathbb{E} \sum_{t=0}^{\infty} A_t \leq \mathbb{E} U_0 < \infty$ ，所以该非负级数几乎必然有限。又 $r_t \rightarrow 0$ ，故 $Z_t = U_t - r_t$ 也收敛。 ■

其中的鞅与超鞅收敛工具见第10章；本引理把可求和误差吸收到一个真正的超鞅中。

定理 13.22 均值求根的几乎必然收敛 设 $\mathcal{F}_t$ 包含 $\theta^{(0)}, Y_1, \dots, Y_t$ ，且 $\mathbb{E}[(\theta^{(0)} - \mu)^2] < \infty$ 。若

$$\mathbb{E}[Y_{t+1} | \mathcal{F}_t] = \mu, \quad \mathbb{E}[(Y_{t+1} - \mu)^2 | \mathcal{F}_t] \leq \sigma^2,$$

步长满足式 (13.33) 并最终有 $0 < \alpha_t \leq 1$ ，则式 (13.32) 的 $\theta^{(t)} \rightarrow \mu$ 几乎必然成立。

证明. 记 $e_t = \theta^{(t)} - \mu$ ， $\xi_{t+1} = Y_{t+1} - \mu$ ，则 $e_{t+1} = (1 - \alpha_t)e_t + \alpha_t \xi_{t+1}$ 。初值与条件二阶矩假设递归保证每个有限时刻的 $\mathbb{E} e_t^2$ 有限。舍去有限前缀，令 $0 < \alpha_t \leq 1$ 。条件展开平方，交叉项为零，得到

$$\mathbb{E}[e_{t+1}^2 | \mathcal{F}_t] = (1 - \alpha_t)^2 e_t^2 + \alpha_t^2 \mathbb{E}[\xi_{t+1}^2 | \mathcal{F}_t] \leq e_t^2 - \alpha_t e_t^2 + \alpha_t^2 \sigma^2.$$

对移位序列应用前一引理，取 $Z_t = e_t^2$ ， $A_t = \alpha_t e_t^2$ ， $b_t = \alpha_t^2 \sigma^2$ 。可积性与可求和条件均已核对，故 e_t^2 几乎必然收敛，且 $\sum_t \alpha_t e_t^2 < \infty$ 。若某条样本路径的极限为 $L > 0$ ，最终就有 $e_t^2 \geq L/2$ ，从而 $\sum_t \alpha_t e_t^2 \geq (L/2) \sum_t \alpha_t = \infty$ ，矛盾。所以 $L = 0$ ，得到结论。 ■

平方可和控制噪声，步长和发散排除残留误差。若条件均值有不可忽略偏差，或条件方差失控，证明中的递推不等式就失去依据。对向量非线性递推，还须证明迭代不会逃向无穷远；仅把标量改写为向量，并不能沿用这里的收敛结论。

对一般平均更新方向，步长变化使相同数量的迭代不再代表相同的累计移动量。为了比较随机递推与连续动力学，用已经累积的步长定义算法时间：

$$\tau_0 = 0, \quad \tau_t = \sum_{s=0}^{t-1} \alpha_s, \quad (13.34)$$

并在相邻 $(\tau_t, \theta^{(t)})$ 之间线性插值为 $\hat{\theta}(\tau)$ 。对应平均 ODE 是

$$\dot{\theta}(\tau) = \bar{h}(\theta(\tau)). \quad (13.35)$$

ODE 方法不是说每个随机增量都等于平均增量，而是要求任意固定算法时间窗上的累计随机偏差最终消失。为了保证这种接近，需要满足以下一组

常用条件: $\alpha_t \rightarrow 0$, $\sum_t \alpha_t = \infty$, $\bar{h}$ 局部 Lipschitz, 迭代几乎必然有界, 并对每个 $H > 0$ 有

$$\sup_{\substack{k \geq t \\ \tau_k - \tau_t \leq H}} \left\| \sum_{s=t}^{k-1} \alpha_s (\xi_{s+1} + r_{s+1}) \right\| \rightarrow 0 \quad \text{几乎必然.}$$

在这些条件下, 插值的积分方程相对平均 ODE 只剩一个在有限窗上一致趋零的残差。局部 Lipschitz 与有界性给出该窗口上的统一常数, 应用引理 13.4, 便得到插值与从同一晚期状态出发的 ODE 轨迹在该窗上一致接近。这一步连接的是有限窗轨迹; 再结合平均 ODE 的全局渐近稳定平衡及紧集上的吸引性, 才能得到迭代收敛到该平衡。⁴

对均值根, 平均方程及其解为

$$\dot{\theta} = \mu - \theta, \quad \theta(\tau) = \mu + (\theta(0) - \mu)e^{-\tau}. \quad (13.36)$$

取 $V = (\theta - \mu)^2/2$ 则 $\dot{V} = -(\theta - \mu)^2$, 与前述误差平方证明一致。一般系统可能有多个吸引子; 平均稳定不意味着全局最优。迭代有界性也须证明, 例如建立远处负漂移的径向无界函数。投影到紧凸集虽可强制有界, 却改变了边界上的平均动力学; 不能把所得极限不加论证地叫作原方程的根, 或原根的欧氏投影。

现在转向相关观测。固定核 P 、平稳分布 π , 随机更新为 $H(\theta, Z_t)$ 时, 平均漂移是

$$\bar{h}(\theta) = \int H(\theta, z) \pi(dz). \quad (13.37)$$

即使 Z_t 已平稳, $H(\theta, Z_t) - \bar{h}(\theta)$ 给定过去也未必均值为零。需要把相关误差转成可控制的鞅和边界项。

定义 13.23 Markov 核的 Poisson 方程 固定 P, π 与 π 可积的 $H(\theta, \cdot)$ 。若可测函数 g_θ 满足

$$g_\theta(z) - Pg_\theta(z) = H(\theta, z) - \bar{h}(\theta), \quad Pg_\theta(z) = \int g_\theta(z') P(z, dz'), \quad (13.38)$$

且所用积分有限, 则称其为相应 Poisson 方程的解。

这里的 Poisson 方程属于 Markov 算子, 不是随后用于事件噪声的 Poisson 计数过程。若链对历史满足 $\mathcal{L}(Z_{t+1} | \mathcal{F}_t) = P(Z_t, \cdot)$, 相关变量可积, 则

$$\begin{aligned} H(\theta, Z_t) - \bar{h}(\theta) &= g_\theta(Z_t) - g_\theta(Z_{t+1}) + \Delta M_{t+1}(\theta), \\ \Delta M_{t+1}(\theta) &= g_\theta(Z_{t+1}) - Pg_\theta(Z_t). \end{aligned} \quad (13.39)$$

⁴ V. S. Borkar, *Stochastic Approximation: A Dynamical Systems Viewpoint*, Cambridge University Press, 2008

最后一项给定 $\mathcal{F}_t$ 均值为零；前两项固定参数时会望远镜消去。参数与步长变化时还剩余项，不能直接把它们删掉。

引理 13.24 固定有限链的加权 Poisson 分解 设 P 为固定的有限不可约非周期核，参数递推 $\theta^{(t+1)} = \theta^{(t)} + \alpha_t H(\theta^{(t)}, Z_t)$ 始终位于紧集 K ， H 在 K 上一致有界且关于参数一致 Lipschitz。若正步长单调递减并满足式 (13.33)，且链对所用历史具有上述条件转移核，则 $\sum_{t=0}^n \alpha_t [H(\theta^{(t)}, Z_t) - \bar{h}(\theta^{(t)})]$ 几乎必然收敛。特别地，任意向晚期移动的有限算法时间窗上的尾和趋零。

证明. 记 $q_\theta = H(\theta, \cdot) - \bar{h}(\theta)$ 。有限不可约非周期链几何收敛，且 $\pi q_\theta = 0$ ，所以 $g_\theta = \sum_{j=0}^{\infty} P^j q_\theta$ 绝对一致收敛，并满足 $g_\theta - P g_\theta = q_\theta$ 。对 $q_\theta - q_{\theta'}$ 应用相同几何界，得到有限常数 G, L_g 使 $|g_\theta(z)| \leq G$ 、 $|g_\theta(z) - g_{\theta'}(z)| \leq L_g |\theta - \theta'|$ 。

加权鞅和 $\sum_{t=0}^n \alpha_t \Delta M_{t+1}(\theta^{(t)})$ 的条件方差和被 $4G^2 \sum_t \alpha_t^2$ 控制，因而在 L^2 中有界并几乎必然收敛。剩余项从 m 到 n 作分部求和，得到

$$\begin{aligned} & \sum_{t=m}^n \alpha_t [g_{\theta^{(t)}}(Z_t) - g_{\theta^{(t)}}(Z_{t+1})] \\ &= \alpha_m g_{\theta^{(m)}}(Z_m) - \alpha_n g_{\theta^{(n)}}(Z_{n+1}) \\ &+ \sum_{t=m+1}^n [\alpha_t g_{\theta^{(t)}}(Z_t) - \alpha_{t-1} g_{\theta^{(t-1)}}(Z_t)]. \end{aligned}$$

中间每项绝对值至多 $G(\alpha_{t-1} - \alpha_t) + \alpha_{t-1} L_g |\theta^{(t)} - \theta^{(t-1)}|$ 。有界更新给出 $|\theta^{(t)} - \theta^{(t-1)}| \leq C \alpha_{t-1}$ 。第一部分由单调性望远镜求和，第二部分由平方可和控制，端点因 $\alpha_t \rightarrow 0$ 而消失。故剩余级数也收敛，与鞅和相加即得结论。收敛级数的任意尾区间和一致趋零，自然包含固定算法时间长度对应的索引窗。 ■

例 10.81 中的链取值 0, 2，平稳均值 $\mu = 2/3$ ，且 $P(z - \mu) = 0.7(z - \mu)$ 。对 $H(\theta, z) = z - \theta$ ，可取 $g_\theta(z) = (z - \mu)/(1 - 0.7) = \frac{10}{3}(z - \mu)$ 。它恰好不依赖参数，因此参数变化余项也消失。Poisson 分解没有把相关样本变成独立样本，而是重新组织累计误差。

一般状态空间要另外证明 Poisson 解存在、具有所需矩界且随参数规则变化。若 $Z_{t+1} \sim P_{\theta^{(t)}}(Z_t, \cdot)$ ，则平均漂移也变成 $\bar{h}(\theta) = \int H(\theta, z) \pi_\theta(dz)$ ，相应方程为 $g_\theta - P_\theta g_\theta = H(\theta, \cdot) - \bar{h}(\theta)$ 。每个固定参数下分别遍历并不够：算法不断改变参数，需要在访问区域上统一控制混合速度、Poisson 解的矩及参数 Lipschitz 界，再控制参数变化造成的加权余项。统一几何遍历、适当的矩界与联合有界性是常见充分条件。它们使相关波动在算法时间上可忽略，不能把不稳定的平均根变成稳定根。

13.4.1.3 双时间尺度的随机逼近

有时需要同时更新两个相互依赖的估计。例如，仍用含噪观测估计未知均值，但把估计写成 $u + v$ ： u 根据观测快速补上当前 v 尚未解释的部分， v 则慢慢调整两部分的分配。若两个变量变化同样快，分析时就必须处理它们的相互影响。双时间尺度方法让一个变量更新得相对更快，以便在分析快变量时，把慢变量近似看作暂时固定。一般形式使用两组步长：

$$\begin{aligned} \mathbf{u}^{(t+1)} &= \mathbf{u}^{(t)} + \beta_t [\mathbf{g}(\mathbf{u}^{(t)}, \mathbf{v}^{(t)}) + \boldsymbol{\eta}_{t+1} + \mathbf{r}_{t+1}^u], \\ \mathbf{v}^{(t+1)} &= \mathbf{v}^{(t)} + \alpha_t [\mathbf{f}(\mathbf{u}^{(t)}, \mathbf{v}^{(t)}) + \boldsymbol{\xi}_{t+1} + \mathbf{r}_{t+1}^v]. \end{aligned}$$

这里 $\mathbf{u}^{(t)}, \mathbf{v}^{(t)}$ 是算法变量，不是贯穿温度模型的行动与读数。两组步长都满足 Robbins–Monro 条件，且 $\alpha_t/\beta_t \rightarrow 0$ 时， $\mathbf{u}$ 相对较快， $\mathbf{v}$ 相对较慢。例如 $\beta_t = (t+1)^{-0.6}$ 、 $\alpha_t = (t+1)^{-0.9}$ 满足尺度分离。

快时间上把 $\mathbf{v}$ 暂时固定，得到 $\dot{\mathbf{u}} = \mathbf{g}(\mathbf{u}, \mathbf{v})$ ；若其稳定平衡为 $\mathbf{u}^*(\mathbf{v})$ ，慢时间上再使用 $\dot{\mathbf{v}} = \mathbf{f}(\mathbf{u}^*(\mathbf{v}), \mathbf{v})$ 。一组常用的充分条件是：漂移局部 Lipschitz；快平衡对每个慢状态全局渐近稳定，其吸引性在所访问的紧参数区域上一致，且平衡映射局部 Lipschitz；约化慢 ODE 有全局渐近稳定平衡 $\mathbf{v}^*$ ；联合迭代几乎必然有界；两组鞅差的条件二阶矩在访问区域有统一界，残差在各自有限算法时间窗上可忽略。在这些条件与步长条件下，标准双时间尺度结论给出 $(\mathbf{u}^{(t)}, \mathbf{v}^{(t)}) \rightarrow (\mathbf{u}^*(\mathbf{v}^*), \mathbf{v}^*)$ 。⁵ Markov 背景则需在两个时钟上分别验证相应的 Poisson 与统一混合条件。

⁵ V. S. Borkar, *Stochastic Approximation: A Dynamical Systems Viewpoint*, Cambridge University Press, 2008

示例 13.25 分解同一个未知均值的快慢更新 若 $\mathbb{E}[Y_{t+1} | \mathcal{F}_t] = \mu$ ，取

$$u^{(t+1)} = u^{(t)} + \beta_t (Y_{t+1} - u^{(t)} - v^{(t)}), \quad v^{(t+1)} = v^{(t)} + \alpha_t (u^{(t)} - v^{(t)}).$$

冻结 v 后，快方程 $\dot{u} = \mu - v - u$ 的唯一稳定平衡为 $u^*(v) = \mu - v$ 。代入慢方程得 $\dot{v} = \mu - 2v$ ，于是 $v^* = \mu/2$ ， $u^*(v^*) = \mu/2$ 。快变量估计尚未被 v 解释的部分，慢变量调整两部分的分配。若再满足两组步长条件、统一有界的条件噪声方差、有限二阶矩初值以及联合迭代几乎必然有界，则上述条件给出联合收敛。

尺度分离没有保证快平衡存在，也没有保证其稳定或全局最优。两组步长同阶时，该线性例仍可用联合系统分析，却不能继续使用冻结慢变量的论证。此外，这里的噪声增量是 $\alpha_t \xi_{t+1}$ ，方差尺度为 α_t^2 ；后面扩散模拟的增量为 $\sqrt{h} \xi$ ，方差尺度为 h 。平均 ODE 中噪声在有限算法时间窗消失，SDE 中噪声则保留有限二次变差，两者不能互换。

13.4.1.4 平均动力学的稳定判据

单时间尺度与双时间尺度的收敛条件都要求平均动力学具有稳定的目标。下面专门判断平均更新方向是否满足这一要求；步长与噪声仍需满足前文条件。线性平均漂移常写为

$$\bar{\mathbf{h}}(\boldsymbol{\theta}) = \mathbf{b} - \mathbf{A}\boldsymbol{\theta}. \quad (13.40)$$

若 $\mathbf{A}$ 可逆，平衡为 $\boldsymbol{\theta}^* = \mathbf{A}^{-1}\mathbf{b}$ ，误差满足

$$\dot{\mathbf{e}} = -\mathbf{A}\mathbf{e}. \quad (13.41)$$

稳定性检查 $-\mathbf{A}$ 是否 Hurwitz，即 $\mathbf{A}$ 的特征值实部是否为正。负号不可漏掉。 $\mathbf{A}$ 也未必是某个损失的 Hessian，不能仅凭更新外形套用凸性。

对一般实矩阵，反对称部分的二次型为零，因而 $\mathbf{e}^\top \mathbf{A} \mathbf{e} = \mathbf{e}^\top (\mathbf{A} + \mathbf{A}^\top) \mathbf{e} / 2$ 。若

$$\frac{\mathbf{A} + \mathbf{A}^\top}{2} > \mathbf{0}, \quad (13.42)$$

则欧氏能量 $V = \|\mathbf{e}\|_2^2 / 2$ 严格下降，给出方便的充分条件。它不是必要条件： $\mathbf{A} = \begin{bmatrix} 1 & 10 \\ 0 & 1 \end{bmatrix}$ 的特征值均为 1，而对称部分 $\begin{bmatrix} 1 & 5 \\ 5 & 1 \end{bmatrix}$ 有负特征值。平均误差仍指数稳定，只是欧氏范数可能暂时增大。只要 $-\mathbf{A}$ 为 Hurwitz 矩阵，线性 Lyapunov 方程便为任意 $\mathbf{Q} > \mathbf{0}$ 给出 $\mathbf{P} > \mathbf{0}$ 满足

$$\mathbf{A}^\top \mathbf{P} + \mathbf{P} \mathbf{A} = \mathbf{Q}. \quad (13.43)$$

此时 $V = \mathbf{e}^\top \mathbf{P} \mathbf{e}$ 的导数为 $-\mathbf{e}^\top \mathbf{Q} \mathbf{e}$ 。即使普通欧氏范数会暂时增大，按 $\mathbf{P}$ 加权的误差仍持续下降，所以仍能证明误差趋于零。

时序差分 (temporal difference, TD) 更新提供了一个具体来源。固定只依赖当前状态的行动规则 π 后，设有限状态 S_t 按转移矩阵 $\mathbf{P}_\pi$ 演化，每步收益 R_{t+1} 按当前转移产生，其规律不随时间改变且绝对值有界。取 $0 \leq \gamma < 1$ ，从状态 i 出发的收益价值定义为

$$v_\pi(i) = \mathbb{E}_i^\pi \left[\sum_{k=0}^{\infty} \gamma^k R_{k+1} \right].$$

这里近似的是累计收益的期望，不是某一次随机实现；下标 i 表示把初态固定为 i ，几何级数保证这个期望有限。拆出第一步，并按下一状态作条件平均，便有

$$v_\pi(i) = \mathbb{E}_i^\pi [R_1 + \gamma v_\pi(S_1)].$$

用特征 $\boldsymbol{\phi}(i) \in \mathbb{R}^q$ 的线性组合 $\boldsymbol{\phi}(i)^\top \boldsymbol{\theta}$ 近似 $v_\pi(i)$ ，再以样本转移 $i \rightarrow j$ 及收益 R 替代这个条件平均，便得到更新方向 $\boldsymbol{\phi}(i)[R + \gamma \boldsymbol{\phi}(j)^\top \boldsymbol{\theta} - \boldsymbol{\phi}(i)^\top \boldsymbol{\theta}]$ 。它

用当前值与“一步收益加下一状态值”的差纠正参数。令平稳访问概率为 $\mathbf{d}$ 、 $\mathbf{D} = \text{diag}(\mathbf{d})$ ， Φ 的第 i 行为 $\phi(i)^\top$ ，在同一策略的平稳访问下平均得到

$$\bar{\mathbf{h}}(\theta) = \mathbf{b} - \mathbf{A}_{\text{TD}}\theta, \quad \mathbf{A}_{\text{TD}} = \Phi^\top \mathbf{D}(\mathbf{I} - \gamma \mathbf{P}_\pi) \Phi. \quad (13.44)$$

若 $r_i = \mathbb{E}[R | i]$ ，则 $\mathbf{b} = \Phi^\top \mathbf{D} \mathbf{r}$ 。固定策略的求值关系在这里解释非对称平均矩阵的来源，策略的选择则留给第 15 章。该章主要按成本计价，把本例收益取负即可转换到相应的成本价值约定。

先设所考虑状态的 $d_i > 0$ ，以便 $\|\mathbf{z}\|_{\mathbf{D}} = (\mathbf{z}^\top \mathbf{D} \mathbf{z})^{1/2}$ 为范数。Jensen 不等式给出 $(\mathbf{P}_\pi \mathbf{z})_i^2 \leq \sum_j (P_\pi)_{i,j} z_j^2$ ；乘 d_i 求和，并用平稳性 $\sum_i d_i (P_\pi)_{i,j} = d_j$ ，得到

$$\|\mathbf{P}_\pi \mathbf{z}\|_{\mathbf{D}} \leq \|\mathbf{z}\|_{\mathbf{D}}. \quad (13.45)$$

再由 Cauchy-Schwarz, $\langle \mathbf{z}, \mathbf{P}_\pi \mathbf{z} \rangle_{\mathbf{D}} \leq \|\mathbf{z}\|_{\mathbf{D}}^2$ 。取 $\mathbf{z} = \Phi \mathbf{c}$ ，便有

$$\begin{aligned} \mathbf{c}^\top \mathbf{A}_{\text{TD}} \mathbf{c} &= \|\Phi \mathbf{c}\|_{\mathbf{D}}^2 - \gamma \langle \Phi \mathbf{c}, \mathbf{P}_\pi \Phi \mathbf{c} \rangle_{\mathbf{D}} \\ &\geq (1 - \gamma) \|\Phi \mathbf{c}\|_{\mathbf{D}}^2. \end{aligned} \quad (13.46)$$

若 $\Phi^\top \mathbf{D} \Phi > \mathbf{0}$ ，右侧对 $\mathbf{c} \neq \mathbf{0}$ 严格为正，所以平均矩阵的对称部分正定，具有唯一全局指数稳定平衡。若允许 $d_i = 0$ ，加权量在全空间只是半范数，但上面的求和不等式仍成立；严格结论仍须直接要求加权特征协方差正定，普通满列秩未必足够。离策略采样改变访问权重而不同时改变目标转移，非扩张不等式可能失败，故不能由此推出离策略稳定。

再用标量递推核对平均稳定与噪声条件怎样配合。设 $\theta^{(t+1)} = \theta^{(t)} + \alpha_t [b - a\theta^{(t)} + \xi_{t+1}]$ ， $a > 0$ ，噪声为条件均值零且条件二阶矩不超过 σ^2 ，初值二阶矩有限。令 $e_t = \theta^{(t)} - b/a$ ，则

$$\mathbb{E}[e_{t+1}^2 | \mathcal{F}_t] = (1 - a\alpha_t)^2 e_t^2 + \alpha_t^2 \mathbb{E}[\xi_{t+1}^2 | \mathcal{F}_t].$$

当 $0 < a\alpha_t \leq 1$ ，右侧至多 $e_t^2 - a\alpha_t e_t^2 + \alpha_t^2 \sigma^2$ 。应用已证几乎超鞅引理与两组步长级数，即得 $e_t \rightarrow 0$ 几乎必然；在这个标量例中，论证本身给出路径有界性，无需额外假设。固定步长则除要求 $|1 - a\alpha| < 1$ 外，还会保留非零噪声方差。

再看另一种需要快慢配合的更新：让 y 快速追踪当前 x ，同时让 x 根据 $x + y$ 与目标 c 之间的差慢慢调整。相应递推为

$$y^{(t+1)} = y^{(t)} + \beta_t [x^{(t)} - y^{(t)} + \eta_{t+1}], \quad x^{(t+1)} = x^{(t)} + \alpha_t [c - x^{(t)} - y^{(t)} + \xi_{t+1}].$$

当 $\alpha_t/\beta_t \rightarrow 0$ ，冻结 x 得到快稳定根 $y^*(x) = x$ ；代入慢场得到 $\dot{x} = c - 2x$ ，故候选联合极限为 $(c/2, c/2)$ 。与前一个均值拆分例相比，这里快变量追踪的是慢变量本身，而非未知均值的剩余部分。两例都先求冻结慢变量后的

快平衡，再把快平衡代入慢方程。这只确定了平均动力学的候选极限；证明随机递推也趋于该极限，仍需核对两组步长、噪声或 Markov 混合、残差和联合有界性条件。

13.4.2 随机增量的积分累计

离散更新只需说明每一步使用哪些已知量。把更新间隔缩到连续时间后，还须说明被积系数在时间与随机结果的联合空间中是否可测。以下滤过 $(\mathcal{F}_t)_{t \geq 0}$ 满足通常条件： $\mathcal{F}_0$ 包含概率零集的全部子集，且 $\mathcal{F}_t = \bigcap_{s > t} \mathcal{F}_s$ 。过程、滤过和停时的基础回见第10章。

一个过程 H 适应，表示每个 H_t 对 $\mathcal{F}_t$ 可测。若对每个 T , $(t, \omega) \mapsto H_t(\omega)$ 在 $[0, T] \times \Omega$ 上对 $\mathcal{B}([0, T]) \otimes \mathcal{F}_T$ 可测，则称它渐进可测。可预测过程则对由全部左连续适应过程生成的可预测 σ 代数可测。这两项都包含时间方向的联合可测要求；逐时刻适应本身不够。连续适应过程可预测；若 X 适应且路径右连续、有左极限，则 X_{t-} 可预测，而跳跃后的 X_t 一般不能作为当次跳跃前已知的系数。

连续时间中也可以根据已经观察到的信息决定何时停止。连续停时是取值于 $[0, \infty]$ 的随机变量 τ ，满足 $\{\tau \leq t\} \in \mathcal{F}_t$ 对每个实数 $t \geq 0$ 成立；停止过程 $M_t^\tau = M_{t \wedge \tau}$ 在到达 τ 后保持当时的值。若适应且右连续、有左极限的过程 M 存在递增停时 $\rho_n \rightarrow \infty$ 几乎必然，使每个 M^{ρ_n} 都是真鞅，就称 M 为局部鞅 (local martingale)。这里的“局部”是由随机停止限定的范围：每条路径最终能覆盖任意给定的有限时段，却未保证去掉停止后仍能交换期望与极限。用这样的停止过程先证明结论、再逐步放开停止范围，称为局部化 (localization)。

普通漂移的累计仍是逐路径的 Lebesgue 积分 $\int_0^t b_s ds$ ，要求相应联合可测性及 $\int_0^T |b_s| ds < \infty$ 几乎必然。噪声的累计规则则取决于增量类型：有限次跳跃可以逐事件相加，连续 Brownian 噪声不能这样处理，也不能当作普通可积的时间导数。

13.4.2.1 跳跃增量的积分

令 N_t 为速率 $\lambda > 0$ 的 Poisson 计数过程，相对于共同滤过， $N_t - N_s$ 独立于 $\mathcal{F}_s$ 且服从 $\text{Pois}(\lambda(t-s))$ 。记跳时为 $\tau_1, \tau_2, \dots$ 。有限活动指每个有界时间区间内几乎必然只有有限个事件；它不要求整个无穷时间轴上事件总数有限。对有限实值的可预测过程 H ，定义

$$\int_0^t H_s dN_s = \sum_{\tau_j \leq t} H_{\tau_j}. \quad (13.47)$$

若 $H_s = g(s, X_{s-})$, 第 j 个事件的贡献为 $g(\tau_j, X_{\tau_j-})$ 。事件已经发生后才知道的状态, 不能反过来决定同一事件的可预测幅度。上述和逐路径有定义; 若还要交换期望与求和, 需增加可积性。

对非负可预测 H , Poisson 补偿恒等式为

$$\mathbb{E} \int_0^T H_s dN_s = \lambda \mathbb{E} \int_0^T H_s ds.$$

对简单过程 $H_s = \sum_i H_i \mathbb{1}_{(t_i, t_{i+1}]}(s)$, H_i 对 $\mathcal{F}_{t_i}$ 可测, 等式由 $\mathbb{E}[H_i \Delta N_i] = \lambda \Delta t_i \mathbb{E} H_i$ 逐项相加得到。非负简单可预测函数逼近与单调收敛把它推广到非负 H ; 正负部均可积时推广到有符号 H 。因此 $\lambda \mathbb{E} \int_0^T |H_s| ds < \infty$ 保证跳跃和可积。

原计数同时包含平均增长与随机起伏。扣除平均增长, 得到补偿计数 $\tilde{N}_t = N_t - \lambda t$ 及积分

$$\int_0^t H_s d\tilde{N}_s = \sum_{\tau_j \leq t} H_{\tau_j} - \lambda \int_0^t H_s ds. \quad (13.48)$$

若 $\lambda \mathbb{E} \int_0^T H_s^2 ds < \infty$, 该过程为平方可积鞅, 并满足

$$\mathbb{E} \left| \int_0^T H_s d\tilde{N}_s \right|^2 = \lambda \mathbb{E} \int_0^T H_s^2 ds. \quad (13.49)$$

为核对这点, 先取上述简单过程。每个 $\Delta \tilde{N}_i$ 在 $\mathcal{F}_{t_i}$ 条件下均值为零、方差为 $\lambda \Delta t_i$ 。对 $i < j$, 先在 $\mathcal{F}_{t_j}$ 条件下求期望, 便使 $H_i \Delta \tilde{N}_i H_j \Delta \tilde{N}_j$ 的期望为零。平方展开只剩 $\sum_i \lambda \Delta t_i \mathbb{E} H_i^2$ 。同样的条件期望计算给出任意 $s < t$ 间的鞅等式。简单过程的二阶逼近、上述等距和条件期望的 L^2 连续性完成延拓; 补偿恒等式保证延拓与有限跳跃和表示一致。若每个有限 T 上只有 $\int_0^T H_s^2 ds < \infty$ 几乎必然, 可取

$$\rho_n = \inf \left\{ t : \lambda \int_0^t H_s^2 ds \geq n \right\} \wedge n.$$

累计平方是连续适应的非减过程, 所以首次达到阈值可由当前历史判断, ρ_n 为停时。停止后的累计量不超过 n , 已证等距便保证相应补偿积分为平方可积鞅。各有界区间的累计量有限又使 $\rho_n \uparrow \infty$ 几乎必然, 因此未停止的积分是局部鞅。去掉停止时, 逐路径收敛并不自动保留期望; 还需例如固定时刻上停止变量族的一致可积性, 才能据此得到零均值。

左极限不是无关紧要的记号。例如单位幅度事件有

$$\int_0^t N_{s-} dN_s = \frac{N_t(N_t - 1)}{2}, \quad \sum_{\tau_j \leq t} N_{\tau_j} = \frac{N_t(N_t + 1)}{2}.$$

右侧第二个和使用了事件后的计数, 两者相差 N_t 。若错误地把 N_s 当作可预测系数, 则

$$\mathbb{E} \left[\sum_{\tau_j \leq t} N_{\tau_j} - \lambda \int_0^t N_s ds \right] = \lambda t \neq 0.$$

它不是声称的零均值补偿积分。用 N_{s-} 时, 多出来的这一项恰好消失。

13.4.2.2 连续增量的积分

以下 $\mathbf{W}$ 是在同一滤过下的 m 维标准 Brownian 运动, 分量独立, 其增量独立于过去且协方差为时间长度乘 $\mathbf{I}_m$ 。定义、路径性质以及 $[\mathbf{W}^{(i)}, \mathbf{W}^{(j)}]_t = \delta_{i,j}t$ 回见第 10.4.6.4 节; 本处只构造如何累计这些增量。先用标量驱动, 把可预测简单过程写为 $H_t = \sum_{i=0}^{n-1} H_i \mathbb{I}_{(t_i, t_{i+1}]}(t)$, 其中 $0 = t_0 < \dots < t_n = T$, $H_i \in L^2(\mathcal{F}_{t_i})$ 。定义

$$\int_0^T H_t dW_t := \sum_{i=0}^{n-1} H_i (W_{t_{i+1}} - W_{t_i}). \quad (13.50)$$

系数可以依赖已发生的全部历史, 但不能借用下一段增量。

记 $M_t = \sum_i H_i (W_{t \wedge t_{i+1}} - W_{t \wedge t_i})$ 。对 $s < t$, 包含 s 的区间使用已知系数和 s 之后的零均值增量; 对起点 $t_i \geq s$ 的后续区间, 塔式性质给出

$$\mathbb{E}[H_i \Delta W_i | \mathcal{F}_s] = \mathbb{E}\{\mathbb{E}[H_i \Delta W_i | \mathcal{F}_{t_i}] | \mathcal{F}_s\} = 0.$$

截断到 t 的最后一段同理。因此 $\mathbb{E}[M_t | \mathcal{F}_s] = M_s$, M 是平方可积鞅, 特别地 $\mathbb{E}M_T = 0$ 。再核对平方: 对 $i < j$, $H_i H_j \Delta W_i$ 对 $\mathcal{F}_{t_j}$ 可测, 故

$$\mathbb{E}[H_i H_j \Delta W_i \Delta W_j] = 0, \quad \mathbb{E}[H_i^2 (\Delta W_i)^2] = \Delta t_i \mathbb{E}H_i^2.$$

无界系数时可先截断再用 L^2 极限; 交叉乘积由 Cauchy-Schwarz 保证可积。逐项相加得到 Itô 等距:

$$\mathbb{E} \left(\int_0^T H_t dW_t \right)^2 = \mathbb{E} \int_0^T H_t^2 dt. \quad (13.51)$$

这与 Poisson 等距的推导结构相同, 但此处尚没有逐路径的有限事件和。

对可预测 H , 若 $\mathbb{E} \int_0^T H_t^2 dt < \infty$, 用简单可预测过程在该范数下逼近, 等距关系使积分序列在 L^2 中为 Cauchy 序列, 从而定义与逼近选择无关的积分。条件期望是 L^2 压缩映射, 故鞅性质保留; 所得鞅可取连续版本。渐进可测且平方可积的系数可在 $\mathbb{P} \otimes dt$ 意义下取等价可预测版本, 得到同一积分。若每个有限 T 上只有 $\int_0^T H_t^2 dt < \infty$ 几乎必然, 则取

$$\rho_n = \inf \left\{ t : \int_0^t H_s^2 ds \geq n \right\} \wedge n.$$

这与 Poisson 积分的停止构造相同，只是不再乘速率 λ 。停止后平方积分至多为 n ，所以可用 Itô 等距构造真鞅；这些积分在共同的停止区间上一致，随 $\rho_n \uparrow \infty$ 拼接成连续局部鞅。矩阵系数逐分量积分时，等距右端改为 Frobenius 范数平方。

普通积分与 Brownian 积分的路径粗糙程度不同。路径 A 在 $[0, T]$ 上有有限变差 (finite variation)，是指全部分割 π 上的绝对增量和有共同有限上界：

$$\text{Var}_{[0,T]}(A) = \sup_{\pi} \sum_i |A_{t_{i+1}} - A_{t_i}| < \infty.$$

这里求和的是绝对增量；二次变差则累计增量的平方，两者不是同一性质。对 $A_t = \int_0^t b_s ds$ ，三角不等式给出 $\text{Var}_{[0,T]}(A) \leq \int_0^T |b_s| ds$ ，因此漂移累计具有有限变差。向量情形可逐分量使用同一判断。把漂移与 Brownian 累计合起来，就得到后面换元公式的对象。

定义 13.26 连续 Itô 过程 设 X_0 对 $\mathcal{F}_0$ 可测， b_t 渐进可测， σ_t 可预测，且每个有限 T 上 $\int_0^T (\|b_t\| + \|\sigma_t\|_{\mathbb{F}}^2) dt < \infty$ 几乎必然。过程

$$X_t = X_0 + \int_0^t b_s ds + \int_0^t \sigma_s dW_s$$

称为连续 Itô 过程。漂移积分有有限变差，随机积分是连续局部鞅。

这里系数已经给定；若系数反过来依赖未知的 X_t ，才形成待求解的方程。

积分约定可以由 Brownian 平方直接辨认：

$$W_{t_{i+1}}^2 - W_{t_i}^2 = 2W_{t_i} \Delta W_i + (\Delta W_i)^2.$$

求和并回用二次变差，左端点和趋于 $(W_T^2 - T)/2$ ，右端点和趋于 $(W_T^2 + T)/2$ 。两者差 T ，不是随着网格变细就消失的误差。连续半鞅是可分解为连续局部鞅与连续适应有限变差过程之和的过程；前述 Itô 过程属于这一类。其二次协变差 $[H, X]_t$ 由分割上 $\sum_i \Delta H_i \Delta X_i$ 的概率极限定义。若 A 有限变差且 X 连续，交叉增量和满足

$$\left| \sum_i \Delta A_i \Delta X_i \right| \leq \max_i |\Delta X_i| \text{Var}_{[0,T]}(A) \rightarrow 0.$$

最后一步来自连续路径在紧区间上一致连续。因此这类因子与连续随机项的二次协变差为零，稍后线性方程的积分因子将使用这个性质。对于连续半鞅 H, X ，Stratonovich 积分可定义为

$$\int_0^t H_s \circ dX_s = \int_0^t H_s dX_s + \frac{1}{2} [H, X]_t.$$

对本章的 Itô 过程, 右侧积分按漂移与 Brownian 部分分别计算; 一般半鞅积分使用相应延拓。该定义对应对称端点求和的概率极限。在系数足够光滑的标量模型中, $dX = b_S(X)dt + \sigma(X) \circ dW$ 等价于 Itô 漂移 $b_I = b_S + \sigma\sigma'/2$ 。多维时修正为 $\frac{1}{2} \sum_j (D\sigma_{\cdot j})\sigma_{\cdot j}$ 。Stratonovich 形式保留普通链式法则, 但不能只更换积分符号而不改漂移。上述规则限定连续半鞅; 跳跃换元要另外保留有限差。

13.4.3 随机状态变换的 Itô 公式

读数、能量和损失通常是状态的函数。已知状态怎样累计, 怎样求这些函数的变化? 普通链式法则只保留一阶增量; 连续随机增量的平方会累计为有限量, 一次跳跃又不能视为无穷小位移。这两种情形分别需要二阶修正与完整有限差。

13.4.3.1 连续变化下的 Itô 公式

定理 13.27 Itô 公式 设 X 为定义 13.26 中的过程, $f \in C^{1,2}([0, T] \times \mathbb{R}^d)$, 即时间一阶、空间二阶偏导连续。则经局部化后, 以概率 1 对所有 t 有下列积分等式; 其微分记号为

$$df(t, X_t) = [\partial_t f + \nabla f^\top \mathbf{b}_t + \frac{1}{2} \text{tr}(\sigma_t \sigma_t^\top \nabla^2 f)] dt + \nabla f^\top \sigma_t dW_t. \quad (13.52)$$

各导数在 (t, X_t) 取值。若要对等式直接取期望, 还须漂移项可积, 且随机被积项满足例如 $\mathbb{E} \int_0^T \|\nabla f^\top \sigma_t\|^2 dt < \infty$; 局部鞅本身不保证期望为零。

先说明关键估计, 以免把二阶项当作形式记忆规则。对有界连续适应系数, 局部化后的 Taylor 展开中, 漂移平方和的期望为 $O(|\pi|)$, 漂移与随机项乘积和的 L^1 范数为 $O(|\pi|^{1/2})$; 这里 $|\pi|$ 为分割的最大间距。这些项均消失。相反, 对有界的 $\mathcal{F}_{t_i}$ 可测权重 c_i , 独立增量与正态四阶矩给出

$$\mathbb{E} \left| \sum_i c_i [(\Delta W_i)^2 - \Delta t_i] \right|^2 = 2 \sum_i \mathbb{E}[c_i^2] (\Delta t_i)^2 \leq 2 \sup_i \|c_i\|_\infty^2 T |\pi|.$$

不同 Brownian 分量的交叉乘积也以同样方式趋零。故加权平方项留下时间积分, 而不是零; 矩阵写法恰为 $\text{tr}(\sigma\sigma^\top \nabla^2 f)/2$ 。

把 ΔX_i 中的系数冻结在左端点, 也要控制误差。连续有界系数满足

$$\mathbb{E} \sum_i \left\| \int_{t_i}^{t_{i+1}} (\sigma_s - \sigma_{t_i}) dW_s \right\|^2 = \mathbb{E} \int_0^T \|\sigma_s - \sigma_{\lfloor s \rfloor \pi}\|_F^2 ds \longrightarrow 0.$$

漂移差用普通积分估计；一阶随机项用 Itô 等距控制。在紧区域内, Hessian 一致连续, 空间 Taylor 余项的绝对值和至多为 $\omega(\max_i \|\Delta \mathbf{X}_i\|) \sum_i \|\Delta \mathbf{X}_i\|^2$, 其中 $\omega(r) \rightarrow 0$ 。路径连续使第一个因子趋零, 第二个因子依上述估计在概率上有界; 余项因而依概率趋零。时间一阶项由 $\partial_t f$ 的一致连续性处理。这解释了光滑且系数连续有界时每类项的去向。

一般可测系数不能擅自用左端取样逼近。完整结果先按状态大小及累计可积量停时, 再以简单可预测过程逼近随机系数, 并用连续局部鞅的二次协变差处理上述加权项, 最后令停时递增。这一一般化及 $C^{1,2}$ 版本的完整证明见 Øksendal 的随机微分方程教材第 4 章; 上面的关键估计说明机制, 不替代该一般证明。⁶

例如 $f(x) = x^2$ 给出

$$W_T^2 = 2 \int_0^T W_s dW_s + T, \quad \int_0^T W_s dW_s = (W_T^2 - T)/2.$$

常数系数则有 $\int_0^T c dW_s = cW_T$ 。形式规则 $(dW)^2 = dt$ 、 $dt dW = 0$ 总结了上述累计量级; 它们不能替代可预测性与极限论证。

13.4.3.2 跳跃变化下的 Itô 公式

考虑连续 Itô 部分加有限活动跳跃的右连续过程

$$\mathbf{X}_t = \mathbf{X}_0 + \int_0^t \mathbf{b}_s ds + \int_0^t \boldsymbol{\sigma}_s d\mathbf{W}_s + \int_0^t \boldsymbol{\gamma}_s dN_s,$$

其中 $\boldsymbol{\gamma}$ 可预测、在各事件处有限, $\mathbf{b}, \boldsymbol{\sigma}$ 满足前述局部可积条件。对同样的 $f \in C^{1,2}$, 换元公式为

$$\begin{aligned} f(t, \mathbf{X}_t) - f(0, \mathbf{X}_0) &= \int_0^t [\partial_s f + \nabla f^\top \mathbf{b}_s + \frac{1}{2} \text{tr}(\boldsymbol{\sigma}_s \boldsymbol{\sigma}_s^\top \nabla^2 f)](s, \mathbf{X}_{s-}) ds \\ &\quad + \int_0^t \nabla f(s, \mathbf{X}_{s-})^\top \boldsymbol{\sigma}_s d\mathbf{W}_s \\ &\quad + \int_0^t [f(s, \mathbf{X}_{s-} + \boldsymbol{\gamma}_s) - f(s, \mathbf{X}_{s-})] dN_s. \end{aligned} \quad (13.53)$$

第一行中 $\mathbf{b}_s, \boldsymbol{\sigma}_s$ 是过程系数, 只把 f 的导数在所示点取值。当跳跃次数与状态先被停时截断后, 在相邻事件之间应用连续 Itô 公式, 到事件 τ_j 处再加上精确增量 $f(\tau_j, \mathbf{X}_{\tau_j}) - f(\tau_j, \mathbf{X}_{\tau_j-})$ 。有限次相加, 端点望远镜消去, 即得此式。再去除截断, 因有限活动与局部可积性, 得到每个有限时域上的结论。这一推导不需要把跳幅假设为很小。

⁶ B. Øksendal, *Stochastic Differential Equations: An Introduction with Applications*, Springer, 2003, 6th ed.

若把 $\nabla f^\top d\mathbf{X}$ 统一写在前面, 则还须显式加上

$$\sum_{\tau_j \leq t} [f(\tau_j, \mathbf{X}_{\tau_j}) - f(\tau_j, \mathbf{X}_{\tau_j-}) - \nabla f(\tau_j, \mathbf{X}_{\tau_j-})^\top \Delta \mathbf{X}_{\tau_j}].$$

它不是只有二阶的近似, 而是扣掉已计入一阶项后的全部有限差。对补偿形式 $d\mathbf{X} = \boldsymbol{\beta}_s ds + \boldsymbol{\sigma}_s d\mathbf{W} + \boldsymbol{\gamma}_s d\tilde{N}$, 记 $\Delta_\gamma f = f(s, \mathbf{X}_{s-} + \boldsymbol{\gamma}_s) - f(s, \mathbf{X}_{s-})$, 则 f 的漂移为

$$\partial_s f + \nabla f^\top \boldsymbol{\beta}_s + \frac{1}{2} \text{tr}(\boldsymbol{\sigma}_s \boldsymbol{\sigma}_s^\top \nabla^2 f) + \lambda(\Delta_\gamma f - \nabla f^\top \boldsymbol{\gamma}_s),$$

跳跃鞅项为 $\Delta_\gamma f d\tilde{N}_s$ 。由 $\mathbf{b} = \boldsymbol{\beta} - \lambda \boldsymbol{\gamma}$ 及 $dN = d\tilde{N} + \lambda ds$ 代入即可核对; 取期望仍须检查该新被积项的可积性。

令 $X = N$ 、 $f(x) = x^2$, 每次事件使平方增加 $2N_{s-} + 1$, 所以

$$N_t^2 = \int_0^t (2N_{s-} + 1) dN_s = 2 \int_0^t N_{s-} d\tilde{N}_s + \tilde{N}_t + 2\lambda \int_0^t N_s ds + \lambda t.$$

于是 $\mathbb{E}N_t^2 = (\lambda t)^2 + \lambda t$ 。Brownian 平方的修正为连续的 t , Poisson 平方的修正为事件计数 N_t ; 后者再补偿才分成鞅与平均漂移。把两者都写成“噪声平方等于时间”会丢失事件信息。

13.4.4 随机状态的连续演化

至此我们能累计一个给定系数过程, 也能计算其函数变化。状态模型还多一步: 下一段漂移和噪声幅度由当前未知状态决定, 积分式因而成为关于整条轨迹的方程。先明确方程与解, 再检查成立条件, 最后用线性结构实际求解。

13.4.4.1 随机微分方程与积分表示

定义 13.28 Itô 随机微分方程与强解 在给定的通常滤过概率空间上, 设 $\mathbf{W}$ 为 m 维 Brownian 运动, $\mathbf{X}_0$ 为 $\mathcal{F}_0$ 可测初值。给定联合 Borel 可测系数 $\mathbf{b} : [0, T] \times \mathbb{R}^d \rightarrow \mathbb{R}^d$ 、 $\boldsymbol{\sigma} : [0, T] \times \mathbb{R}^d \rightarrow \mathbb{R}^{d \times m}$, Itô 随机微分方程的扩散形式为

$$d\mathbf{X}_t = \mathbf{b}(t, \mathbf{X}_t) dt + \boldsymbol{\sigma}(t, \mathbf{X}_t) d\mathbf{W}_t. \quad (13.54)$$

解是满足局部可积条件的连续适应过程, 使

$$\mathbf{X}_t = \mathbf{X}_0 + \int_0^t \mathbf{b}(s, \mathbf{X}_s) ds + \int_0^t \boldsymbol{\sigma}(s, \mathbf{X}_s) d\mathbf{W}_s$$

以概率 1 对所有 t 同时成立。若解适应于初值和给定驱动的历史所生成、完成并取右连续版本的滤过，则称为强解；它不另外使用随机信息。

再给定速率 λ 的 Poisson 过程 N ，并规定 $\mathbf{W}, N, \mathbf{X}_0$ 相互独立，以其共同历史生成滤过；更一般的模型必须显式保证两类驱动在共同滤过下仍有前述增量与补偿性质。有限活动跳跃扩展为

$$\mathbf{X}_t = \mathbf{X}_0 + \int_0^t \mathbf{b}(s, \mathbf{X}_{s-}) ds + \int_0^t \boldsymbol{\sigma}(s, \mathbf{X}_{s-}) d\mathbf{W}_s + \int_0^t \boldsymbol{\gamma}(s, \mathbf{X}_{s-}) dN_s. \quad (13.55)$$

此时要求解右连续且有左极限。若采用补偿积分，须把漂移改为 $\mathbf{b} + \lambda \boldsymbol{\gamma}$ 才能表示同一个模型。强解的定义相应包含 N 的历史。

例如 $d\mathbf{X}_t = -\lambda_0 \mathbf{X}_{t-} dt + \sigma d\mathbf{W}_t + c dN_t$ 描述连续泄漏、连续扰动以及每个事件带来的 c 单位突变，其中 $\lambda_0 > 0$ 为泄漏率， λ 仍为事件速率。连续时间只是时间参数连续，不意味着路径可微或没有跳跃。

弱解允许概率空间、驱动和过程一起作为待求对象，但它们必须满足同样的驱动联合条件、初值分布及积分方程。路径唯一性比较同一空间、同一初值和同一驱动上的两个解，要求它们不可区分，即几乎必然在所有时刻相同。分布唯一性则只要求任意弱解的状态路径分布相同：扩散情形在连续路径空间上比较，跳跃情形在右连续有左极限的路径空间上比较。因此“弱”不是数值精度较低，“强”也不是稳定性更强。给定噪声后能否逐路径确定状态，与只确定状态的概率规律，是不同要求。

13.4.4.2 随机微分方程的存在与唯一条件

随机 Picard 迭代要同时控制整个时间区间的误差，而 Itô 等距只直接控制某个终点。下面的最大不等式补上这一点。

引理 13.29 二阶鞅最大不等式 若 $\mathbf{M}$ 是右连续平方可积鞅，则

$$\mathbb{E} \sup_{t \leq T} \|\mathbf{M}_t\|^2 \leq 4\mathbb{E} \|\mathbf{M}_T\|^2.$$

证明. $\|\mathbf{M}_t\|$ 由条件 Jensen 不等式为非负次鞅。记 $S = \sup_{t \leq T} \|\mathbf{M}_t\|$ 。在有限网格首次越过 a 的时刻条件化，得 $a\mathbb{P}(S_{\text{grid}} > a) \leq \mathbb{E}[\|\mathbf{M}_T\| \mathbb{1}_{\{S_{\text{grid}} > a\}}]$ 。取越来越密且包含 T 的网格，由右连续性得到同样的 S 不等式。对 $a \in [0, R]$ 积分并用尾积分公式，

$$\mathbb{E}(S \wedge R)^2 \leq 2\mathbb{E}[\|\mathbf{M}_T\|(S \wedge R)] \leq 2\|\mathbf{M}_T\|_{L^2} \|S \wedge R\|_{L^2}.$$

若右端第二因子为零结论显然；否则除去它再平方，令 $R \uparrow \infty$ 即可。 ■

定理 13.30 SDE 强解的存在唯一性 设 W 在通常滤过下为标准 Brownian 运动, $X_0 \in L^2(\mathcal{F}_0)$ 。联合 Borel 可测的 b, σ 在 $[0, T]$ 上满足统一全局 Lipschitz 与线性增长条件

$$\begin{aligned}\|b(t, x) - b(t, y)\| + \|\sigma(t, x) - \sigma(t, y)\|_F &\leq L\|x - y\|, \\ \|b(t, x)\|^2 + \|\sigma(t, x)\|_F^2 &\leq C(1 + \|x\|^2).\end{aligned}$$

则式 (13.54) 存在唯一强解, 具有路径唯一性, 且 $\mathbb{E} \sup_{t \leq T} \|X_t\|^2 < \infty$ 。

证明. 在短区间 $[a, a+h]$ 固定平方可积初值 ξ , 取连续适应过程的空间, 范数为 $\|Z\|_{s^2}^2 = \mathbb{E} \sup_{a \leq t \leq a+h} \|Z_t\|^2$, 过程按不可区分等价。这是完备空间: Cauchy 列可选子列几乎必然一致收敛, 极限连续且适应, 再用范数 Cauchy 性质得到 s^2 收敛。定义

$$(\mathcal{I}Z)_t = \xi + \int_a^t b(s, Z_s) ds + \int_a^t \sigma(s, Z_s) dW_s.$$

Borel 系数与连续适应过程的复合渐进可测; 增长界、Cauchy-Schwarz、Itô 等距和最大不等式使 $\mathcal{I}$ 映回该空间。对两过程作差, 同样的估计给出

$$\|\mathcal{I}Z - \mathcal{I}Y\|_{s^2}^2 \leq (2hL^2 + 8L^2) \int_a^{a+h} \mathbb{E} \|Z_s - Y_s\|^2 ds \leq 2L^2 h(h+4) \|Z - Y\|_{s^2}^2.$$

取 h 使最后系数小于 1, 压缩映射定理给出唯一不动点。从常值过程开始的 Picard 迭代只用 ξ 和驱动历史, 极限为强解。用区间末状态作为下一段初值, 在同样长度的有限多个区间上接续得到 $[0, T]$ 解。

为核对矩与无爆炸, 记 $S(t) = \mathbb{E} \sup_{r \leq t} \|X_r\|^2$ 。三项平方界与前述估计给出

$$S(t) \leq 3\mathbb{E}\|X_0\|^2 + 3C(T+4) \int_0^t [1 + S(s)] ds.$$

引理 13.4 给出有限上界。对同初值同驱动的两个 s^2 解, 记

$$D(t) = \mathbb{E} \sup_{r \leq t} \|X_r - Y_r\|^2.$$

同样的估计给出

$$D(t) \leq 2L^2(T+4) \int_0^t D(s) ds.$$

再用该引理便有 $D = 0$ 。对一般连续局部解, 先在两者离开半径 R 的球之前使用同一估计; 再令 $R \uparrow \infty$, 由增长界及连续性去掉停时, 得到路径唯一性。■

上述构造的每次迭代都是初值与驱动的同个可测函数, 极限的分布因此由它们的联合分布确定, 也给出这里的分布唯一性。只有局部 Lipschitz 时, 截断系数先给出离开任意有界区域前的解; 线性增长或合适 Lyapunov 矩界还需用来排除爆炸。光滑系数本身不够, 零扩散下的 $\dot{X} = X^2$ 已经是反例。

对式 (13.55), 有限速率 N 在 $[0, T]$ 上只有有限跳时。在两次事件间解扩散方程, 在 τ_j 处设 $\mathbf{X}_{\tau_j} = \mathbf{X}_{\tau_j-} + \gamma(\tau_j, \mathbf{X}_{\tau_j-})$ 。若扩散部分满足上述无爆炸条件, 且 γ 为有限值可测映射, 这一有限次拼接给出路径上的存在与唯一性。若还要求二阶矩统一有界, 可用统一线性增长的跳幅以及补偿积分的最大不等式得到同类 Grönwall 界; 全局 Lipschitz 跳幅是常用的进一步充分条件。状态依赖且可爆炸的事件速率不在此固定有限速率论证之内; 不能在有限时间允许无穷次事件后仍沿用有限拼接。

13.4.4.3 线性随机方程的解析求解

线性结构把“系数依赖解”的难点拆开。考虑

$$d\mathbf{X}_t = (\mathbf{A}_t \mathbf{X}_t + \mathbf{c}_t) dt + \mathbf{G}_t d\mathbf{W}_t,$$

其中 $\mathbf{A}, \mathbf{c}, \mathbf{G}$ 均为确定性函数, $\mathbf{A}, \mathbf{c}$ 局部可积, $\|\mathbf{G}_t\|_F^2$ 局部可积, $\mathbf{X}_0 \in L^2$ 且与 Brownian 驱动独立。绝对连续的状态转移矩阵 $\Phi(t, s)$ 依旧满足组合律。对 $\Phi(0, t)\mathbf{X}_t$ 使用乘积公式: 确定性因子有有限变差, 与随机项的二次协变差为零, 且 $\partial_t \Phi(0, t) = -\Phi(0, t)\mathbf{A}_t$ 几乎处处成立。两项漂移相消, 积分并乘回 $\Phi(t, 0)$ 得

$$\mathbf{X}_t = \Phi(t, 0)\mathbf{X}_0 + \int_0^t \Phi(t, s)\mathbf{c}_s ds + \int_0^t \Phi(t, s)\mathbf{G}_s d\mathbf{W}_s. \quad (13.56)$$

有限区间上 Φ 有界, 故各积分有定义; 反向使用乘积公式可直接验证方程。相减后的齐次线性 ODE 又给出唯一性。这里不要求 $\mathbf{A}$ 在不同时刻交换。

标量 Ornstein–Uhlenbeck (OU) 过程把泄漏记忆与持续噪声放在一起:

$$dX_t = -\lambda X_t dt + \sigma dW_t, \quad \lambda > 0. \quad (13.57)$$

由 $d(e^{\lambda t} X_t) = \sigma e^{\lambda t} dW_t$ 得

$$X_t = e^{-\lambda t} X_0 + \sigma \int_0^t e^{-\lambda(t-s)} dW_s.$$

若 $X_0 = x_0$ 为常数，第二项为零均值高斯，因而 $X_t \sim \mathcal{N}(e^{-\lambda t} x_0, \sigma^2(1 - e^{-2\lambda t})/(2\lambda))$ 。同一个积分还决定不同时刻的关联：对 $s \leq t$,

$$X_t = e^{-\lambda(t-s)} X_s + \sigma \int_s^t e^{-\lambda(t-r)} dW_r, \quad \text{Cov}(X_s, X_t) = e^{-\lambda(t-s)} \text{Var}(X_s).$$

后段积分独立于 $\mathcal{F}_s$ 。把每个时刻的上述高斯边缘独立抽一次，虽能复现截面分布，却不能复现这条轨迹的联合规律。




图 13.6 OU 模型的路径与截面。取 $\lambda = 1, \sigma = 0.6, X_0 = 1$ ，左侧为按精确高斯转移生成的四条网格轨迹与理论均值，右侧为 $t = 0.5, 2$ 的解析边缘密度。折线只连接模拟网格点，不是可微的连续样本路径。截面给出单时刻概率，时间间的相关性还由共同噪声与转移决定。

13.4.5 随机状态的分布演化

逐路径的积分式不一定最适合回答“某时刻落在何处”的概率问题。线性模型可传播少量矩，一般模型则要传播分布对测试函数的作用。两者都来自同一演化规律，但矩摘要只有在附加分布条件下才是完整描述。

13.4.5.1 线性演化下的均值与协方差

对式 (13.56)，记 $\mathbf{m}_t = \mathbb{E}X_t, \mathbf{P}_t = \text{Cov}(X_t)$ 。随机积分为零均值、与初值独立，故

$$\begin{aligned} \mathbf{m}_t &= \Phi(t, 0) \mathbf{m}_0 + \int_0^t \Phi(t, s) \mathbf{c}_s ds, \\ \mathbf{P}_t &= \Phi(t, 0) \mathbf{P}_0 \Phi(t, 0)^\top + \int_0^t \Phi(t, s) \mathbf{G}_s \mathbf{G}_s^\top \Phi(t, s)^\top ds. \end{aligned}$$

这里积分中的 $\mathbf{G}_s \mathbf{G}_s^\top$ 是确定性矩阵。若扩散系数也随机，就不能直接沿用这组确定性协方差公式；即使均方可积，取期望时也必须保留扩散系数的随机性及其与状态的关系。两式绝对连续，对几乎处处的 t 有

$$\dot{\mathbf{m}}_t = \mathbf{A}_t \mathbf{m}_t + \mathbf{c}_t, \quad (13.58)$$

$$\dot{\mathbf{P}}_t = \mathbf{A}_t \mathbf{P}_t + \mathbf{P}_t \mathbf{A}_t^\top + \mathbf{G}_t \mathbf{G}_t^\top. \quad (13.59)$$

也可令 $\tilde{\mathbf{X}} = \mathbf{X} - \mathbf{m}$ ，直接用乘积 Itô 公式得到

$$\begin{aligned} d(\tilde{\mathbf{X}} \tilde{\mathbf{X}}^\top) &= (\mathbf{A} \tilde{\mathbf{X}} \tilde{\mathbf{X}}^\top + \tilde{\mathbf{X}} \tilde{\mathbf{X}}^\top \mathbf{A}^\top + \mathbf{G} \mathbf{G}^\top) dt \\ &\quad + \mathbf{G} d\mathbf{W} \tilde{\mathbf{X}}^\top + \tilde{\mathbf{X}} d\mathbf{W}^\top \mathbf{G}^\top. \end{aligned}$$

二阶矩界使随机积分取期望后消失，得到相同结论。漂移传播已有不确定性， $\mathbf{G} \mathbf{G}^\top$ 持续注入新的不确定性；后面的离散预测也有同样两项。

OU 过程的初值只需平方可积并独立于驱动，就有

$$\mathbb{E} X_t = e^{-\lambda t} \mathbb{E} X_0, \quad (13.60)$$

$$\text{Var}(X_t) = e^{-2\lambda t} \text{Var}(X_0) + \frac{\sigma^2}{2\lambda} (1 - e^{-2\lambda t}). \quad (13.61)$$

均值衰减而方差不消失。对 $f(x) = x^2$ 换元可再次核对： $d(X_t^2) = (-2\lambda X_t^2 + \sigma^2) dt + 2\sigma X_t dW_t$ 。若漏掉 $\sigma^2 dt$ ，便会错误地认为持续噪声不留下方差。当初始分布取 $\mathcal{N}(0, \sigma^2/(2\lambda))$ 时，OU 过程平稳；一般初态只是在长期趋于该分布，而非每条路径趋于零。 $\sigma = 0$ 时稳态退化为 δ_0 。非高斯初值的有限时刻分布通常仍非高斯，上面两个矩不能单独确定它。

13.4.5.2 一般演化下的分布与密度

设确定性系数与适当的解唯一性使 $\mathbf{X}$ 成为 Markov 过程。要知道分布怎样变化，可先观察任意光滑“读数” $\varphi(\mathbf{X}_t)$ 的短时期望。

定义 13.31 Itô 扩散的生成元 记 $\mathbb{E}_{t,\mathbf{x}}$ 为从时刻 t 的状态 $\mathbf{x}$ 出发的期望。对属于算子定义域的测试函数，生成元定义为

$$(\mathcal{L}_t \varphi)(\mathbf{x}) = \lim_{h \downarrow 0} \frac{\mathbb{E}_{t,\mathbf{x}} \varphi(\mathbf{X}_{t+h}) - \varphi(\mathbf{x})}{h}.$$

对连续系数的扩散，令 $\mathbf{a} = \sigma \sigma^\top$ ；在极限与期望可交换时，Itô 公式给出

$$\mathcal{L}_t \varphi = \mathbf{b}^\top \nabla \varphi + \frac{1}{2} \text{tr}(\mathbf{a} \nabla^2 \varphi).$$

从积分 Itô 公式取条件期望，除以 h 再令 $h \downarrow 0$ ，即得最后一式。例如取光滑紧支撑 φ ，并使系数在相关区域有界，可以先局部化来核对该极限。

若时间系数仅可测，则优先使用下面的积分弱式，不强求每个时刻的点态极限。

写 μ_t 为状态分布。在鞅项可积且均值为零时，

$$\int \varphi d\mu_t - \int \varphi d\mu_0 = \int_0^t \int \mathcal{L}_s \varphi d\mu_s ds.$$

这是不要求密度存在的弱演化式。对有限活动的原计数驱动，还须加上 $\lambda[\varphi(\mathbf{x} + \boldsymbol{\gamma}(t, \mathbf{x})) - \varphi(\mathbf{x})]$ ；若方程用补偿驱动，则漂移算子相应增加 $\lambda[\varphi(\mathbf{x} + \boldsymbol{\gamma}) - \varphi(\mathbf{x}) - \nabla \varphi^\top \boldsymbol{\gamma}]$ 。离散跳跃由有限差算子表达，不是无条件多加一个扩散 Hessian 项。

若 μ_t 有密度 $p(t, \mathbf{x})$ ，代入扩散弱式，漂移项分部积分一次，扩散项分部积分两次，得到

$$\begin{aligned} \int \varphi \partial_t p d\mathbf{x} &= \int \left[\sum_i b_i \partial_i \varphi + \frac{1}{2} \sum_{i,j} a_{i,j} \partial_{i,j} \varphi \right] p d\mathbf{x} \\ &= \int \varphi \left[-\sum_i \partial_i (b_i p) + \frac{1}{2} \sum_{i,j} \partial_i \partial_j (a_{i,j} p) \right] d\mathbf{x}. \end{aligned}$$

测试函数紧支撑时无无穷远边界项；有界区域还需与模型匹配的边界条件。因此得到 Fokker-Planck 方程

$$\partial_t p = -\sum_i \partial_i (b_i p) + \frac{1}{2} \sum_{i,j} \partial_i \partial_j (a_{i,j} p). \quad (13.62)$$

弱等式先成立；经典逐点形式另需 p 和系数的时间、空间正则性。例如全空间光滑有界系数与一致椭圆扩散是获得正时间光滑密度的一组常用充分条件。这里一致椭圆 (uniformly elliptic) 指存在固定 $c > 0$ ，使所讨论的时间与状态范围内，

$$\mathbf{v}^\top \mathbf{a}(t, \mathbf{x}) \mathbf{v} \geq c \|\mathbf{v}\|_2^2 \quad \text{对所有 } \mathbf{v} \in \mathbb{R}^d \text{ 成立.}$$

也就是每个方向的噪声强度都有同一个正下界。这比每个 $(t, \mathbf{x})$ 处分别正定更强：后者仍允许最小特征值随状态或时间趋于零。退化扩散可能把概率留在低维集合，不能预先假定全维光滑密度。

把密度方程写成 $\partial_t p = -\nabla \cdot \mathbf{J}$ ，其中 $J_i = b_i p - \frac{1}{2} \sum_j \partial_j (a_{i,j} p)$ 。在 $p > 0$ 处，令 $\mathbf{v} = \mathbf{J}/p$ ，便得到概率流速度

$$\mathbf{v}(t, \mathbf{x}) = \mathbf{b}(t, \mathbf{x}) - \frac{1}{2} [\operatorname{div} \mathbf{a}(t, \mathbf{x}) + \mathbf{a}(t, \mathbf{x}) \nabla_{\mathbf{x}} \log p(t, \mathbf{x})], \quad (\operatorname{div} \mathbf{a})_i = \sum_j \partial_j a_{i,j}. \quad (13.63)$$

式中的 $\mathbf{s}_t(\mathbf{x}) = \nabla_{\mathbf{x}} \log p(t, \mathbf{x})$ 称为状态密度分数 (state score)，表示在状态空间中对数密度上升最快的局部方向。它对状态 $\mathbf{x}$ 求导；前面统计几何

中的参数得分对模型参数求导，两者的自变量及向量维数通常不同。例如 OU 过程某个时刻的边缘为 $\mathcal{N}(\mathbf{m}_t, \mathbf{v}_t)$ 且 $v_t > 0$ 时， $s_t(\mathbf{x}) = -(\mathbf{x} - \mathbf{m}_t)/v_t$ ，直接指向密度中心，距中心越远时幅度越大。若此速度的 ODE 流存在、连续性方程适定，并具有同样初始密度及边界通量，那么 ODE 产生的状态分布就与原扩散在各个时刻的边缘分布相同。只有 $\mathbf{a}$ 不依赖状态时，散度项才消失。各时刻的分布相同，仍不意味着两种模型产生相同的轨迹规律：ODE 在给定初态后不再引入新的噪声，而扩散不断注入随机增量。

时间反演也不是把 b 单独取负。固定终点 T ，用正向反演时钟 s 定义 $\hat{\mathbf{X}}_s = \mathbf{X}_{T-s}$ 。在正密度、系数和密度足够光滑、扩散非退化及相应可积条件下，其反演滤过中的扩散矩阵为 $\mathbf{a}(T-s, \mathbf{x})$ ，漂移为

$$\hat{\mathbf{b}}(s, \mathbf{x}) = -\mathbf{b}(T-s, \mathbf{x}) + \operatorname{div} \mathbf{a}(T-s, \mathbf{x}) + \mathbf{a}(T-s, \mathbf{x}) \nabla_{\mathbf{x}} \log p(T-s, \mathbf{x}).$$

例如可先在远离奇异端点的紧时间区间上取光滑有界系数、一致椭圆矩阵、正的光滑密度及局部可积的分数，并另保证反演方程无爆炸。反演 Brownian 运动相对于反演历史定义，不能当作原 Brownian 路径简单反号。这一结果还用到正反方向转移的 Bayes 关系；前向密度方程本身不确定时间联合规律。在生成模型中用估计分数替换真实分数，会再引入模型误差。

13.4.6 随机轨迹的模拟与采样

有限时域模拟问数值状态是否接近给定随机模型；长期采样问所构造的链是否按目标分布取样。前一问题可以比较耦合路径或测试函数，后一问题还要检查不变性、遍历性和混合速度。两者都使用随机数，但保证的对象不同。

13.4.6.1 有限时域的轨迹模拟

固定 T ，取 $t_k = kh$ 、 $n = T/h$ 为整数，初值 $\hat{\mathbf{X}}_0 = \mathbf{X}_0$ 。Euler-Maruyama 方法冻结每段左端的系数：

$$\hat{\mathbf{X}}_{k+1} = \hat{\mathbf{X}}_k + h\mathbf{b}(t_k, \hat{\mathbf{X}}_k) + \boldsymbol{\sigma}(t_k, \hat{\mathbf{X}}_k)\sqrt{h}\boldsymbol{\varepsilon}_k, \quad \boldsymbol{\varepsilon}_k \stackrel{\text{iid}}{\sim} \mathcal{N}(\mathbf{0}, \mathbf{I}_m). \quad (13.64)$$

新噪声与初值、先前噪声独立。扩散项乘 $\sqrt{h}$ ，才能每单位时间累计有限方差；随机逼近中的步长乘观测误差通常是 $h\xi_k$ ，方差尺度为 h^2 ，两者不是同一极限。

Poisson 驱动须另生成 $\Delta N_k \sim \text{Pois}(\lambda h)$ ，并按驱动假设与 Brownian 增量独立。网格法用 $\gamma(t_k, \hat{\mathbf{X}}_k)\Delta N_k$ 冻结该段跳幅；补偿版本改用 $\Delta N_k - \lambda h$ 。当一段内有多事件且跳幅依赖状态时，这种冻结不同于逐事件更新。事件适配法则依次采样独立 $\text{Exp}(\lambda)$ 等待时间，把跳时插入网格，在事件间

模拟扩散、在事件处用跳前状态更新。这里 Brownian 增量仍按各段实际长度采样, 不能用高斯增量冒充跳跃计数。

同一噪声下的状态误差 要比较数值轨迹与真实轨迹的强误差, 必须让两者使用同一个随机驱动, 即令 $\sqrt{h}\varepsilon_k = \mathbf{W}_{t_{k+1}} - \mathbf{W}_{t_k}$ 。对自治系数, 在全局 Lipschitz、线性增长和 $\mathbf{X}_0 \in L^2$ 条件下, 固定有限时域有

$$\max_{0 \leq k \leq n} (\mathbb{E} \|\mathbf{X}_{t_k} - \hat{\mathbf{X}}_k\|^2)^{1/2} \leq C_T h^{1/2}.$$

显式时间依赖时, 一组充分条件是统一状态 Lipschitz, 并有 $\|\mathbf{b}(t, \mathbf{x}) - \mathbf{b}(s, \mathbf{x})\| + \|\sigma(t, \mathbf{x}) - \sigma(s, \mathbf{x})\|_F \leq K(1 + \|\mathbf{x}\|)|t - s|^{1/2}$ 。常数依赖 T 和系数界, 不是无限时域的统一保证。

估计机制与存在性证明相连。定义连续插值

$$\begin{aligned} \hat{\mathbf{X}}_t &= \mathbf{X}_0 + \int_0^t \mathbf{b}(\eta(s), \hat{\mathbf{X}}_{\eta(s)}) ds \\ &\quad + \int_0^t \sigma(\eta(s), \hat{\mathbf{X}}_{\eta(s)}) d\mathbf{W}_s, \end{aligned}$$

其中 $\eta(s) = t_{\lfloor s/h \rfloor}$, 插值在网格上等于算法值。增长界先给出统一二阶矩, 并由等距得到 $\sup_{s \leq T} \mathbb{E} \|\hat{\mathbf{X}}_s - \hat{\mathbf{X}}_{\eta(s)}\|^2 \leq C_T h$ 。相减积分方程, 用 Lipschitz、最大不等式和时间正则性得

$$E(t) := \mathbb{E} \sup_{r \leq t} \|\mathbf{X}_r - \hat{\mathbf{X}}_r\|^2 \leq C_T \int_0^t E(s) ds + C_T h.$$

Grönwall 给出 $E(T) \leq C'_T h$, 开方即得到 $O(h^{1/2})$ 的强误差界。加性噪声等结构可能提高阶数, 但不是一般乘性噪声的保证; 跳跃扩展还需另核对跳幅、驱动耦合与事件处理。

测试函数下的期望误差 弱误差不逐路径相减, 而是比较读数的期望。一组方便的自治充分条件是漂移、扩散与测试函数 φ 具有至四阶连续有界导数, 并满足增长和所需矩条件; 更保守地可取它们本身及至四阶导数均有界。此时

$$|\mathbb{E}\varphi(\mathbf{X}_T) - \mathbb{E}\varphi(\hat{\mathbf{X}}_n)| \leq C_{\varphi, T} h.$$

其机制是对剩余期望函数 $u(t, \mathbf{x}) = \mathbb{E}_{t, \mathbf{x}} \varphi(\mathbf{X}_T)$ 作局部展开。在其相应导数有界的条件下, 精确转移与一次 Euler 转移都给出 $u + h\mathcal{L}u + O(h^2)$ 。把每步的期望差望远镜相加, $n = T/h$ 个局部 $O(h^2)$ 误差累计为 $O(h)$ 。这里引用标准弱收敛结果, 导数与矩条件用于保证展开余项统一可积; 不能仅凭二阶矩和状态 Lipschitz 就断言弱一阶。⁷

⁷ P. E. Kloeden, E. Platen, *Numerical Solution of Stochastic Differential Equations*, Springer, 1992

弱阶较高不说明两条样本轨迹更接近。例如独立生成的两个同分布终点对所有可积测试函数期望完全相同，彼此状态距离却不为零。有限时间弱误差还不能直接交换 $h \downarrow 0$ 与 $T \uparrow \infty$ ，长期步长偏差必须单独分析。

13.4.6.2 目标分布下的长期采样

若目标是从指定分布抽样，就需要反过来设计状态更新：希望经过足够长的运行后，状态按目标分布出现。设目标密度 $\pi > 0$ 光滑且可归一化。过阻尼 Langevin 模型把状态向目标密度较高的方向推动，同时保留 Brownian 扰动：

$$d\mathbf{X}_t = \frac{1}{2} \nabla \log \pi(\mathbf{X}_t) dt + d\mathbf{W}_t. \quad (13.65)$$

代入 Fokker-Planck 通量， $\mathbf{b}\pi - \nabla\pi/2 = \mathbf{0}$ 。在方程无爆炸、边界通量为零及密度方程适定等条件下，这证明 π 不变。从其他初态收敛还需遍历条件；例如 $\pi \propto e^{-U}$ ， U 光滑强凸且梯度全局 Lipschitz 时，噪声非退化与向内漂移提供常用保证。多峰势能可能保持同一目标却混合很慢。

即使连续模型正确，离散化也会改变稳态。取 $\pi = \mathcal{N}(0, 1)$ ，则 $X_{k+1} = (1 - h/2)X_k + \sqrt{h}\varepsilon_k$ 。只有 $0 < h < 4$ 时这一递推稳定，其稳态方差为

$$\frac{h}{1 - (1 - h/2)^2} = \frac{1}{1 - h/4},$$

并非 1。减小步长减小偏差，但在相同计算步数下也缩短模拟时间；有限预算须同时考虑初态遗留、相关性和离散误差。

Hamilton 蒙特卡洛(HMC)使用另一种构造。若 $\pi(\mathbf{q}) \propto \exp[-U(\mathbf{q})]$ ，引入独立 $\mathbf{p} \sim \mathcal{N}(\mathbf{0}, \mathbf{M})$ ，联合密度为 $\rho(\mathbf{q}, \mathbf{p}) \propto \exp[-H(\mathbf{q}, \mathbf{p})]$ 。精确 Hamilton 流保持能量和体积，因此保持 ρ ；蛙跳只保持体积与可逆结构，需要接受校正补偿能量误差。固定步长 h 与步数 L ，记 $T = R \circ \Psi_h^L$ ，其中 $R(\mathbf{q}, \mathbf{p}) = (\mathbf{q}, -\mathbf{p})$ 。前面已证明 $R\Psi_h R = \Psi_h^{-1}$ ，故 $T^2 = I$ ，且 $|\det DT| = 1$ 。对 $\mathbf{z}' = T\mathbf{z}$ ，接受概率取

$$\alpha(\mathbf{z}) = \min\{1, \exp[-H(\mathbf{z}') + H(\mathbf{z})]\}. \quad (13.66)$$

定理 13.32 HMC 提议的详细平衡 若 T 是可微、体积保持的对合，则以概率 $\alpha(\mathbf{z})$ 移至 $T\mathbf{z}$ ，否则留在 $\mathbf{z}$ 的核，对密度 ρ 满足详细平衡。

证明. 接受部分的密度权重为 $\rho(\mathbf{z})\alpha(\mathbf{z}) = \min\{\rho(\mathbf{z}), \rho(T\mathbf{z})\}$ 。对任意有界可测函数 $g(\mathbf{z}, \mathbf{z}')$ ，作变量替换 $\mathbf{y} = T\mathbf{z}$ ，由 $T^2 = I$ 和单位绝对 Jacobian，

$$\begin{aligned} & \int g(\mathbf{z}, T\mathbf{z}) \min\{\rho(\mathbf{z}), \rho(T\mathbf{z})\} d\mathbf{z} \\ &= \int g(T\mathbf{y}, \mathbf{y}) \min\{\rho(T\mathbf{y}), \rho(\mathbf{y})\} d\mathbf{y}. \end{aligned}$$

这证明接受部分在交换出发与到达状态后不变。拒绝部分集中在对角线 $\mathbf{z}' = \mathbf{z}$ ，本身对称，两者相加即为详细平衡。 ■

一轮算法因而是：保留当前位置并重新抽取高斯动量；按三子步蛙跳执行 L 次；翻转末端动量并计算 ΔH ；抽取独立均匀数，按 $\min(1, e^{-\Delta H})$ 接受，否则保留原位置。动量刷新是联合目标的条件抽样，保持 ρ ；再接上述核仍保持 ρ ，边缘化动量得到位置目标 π 。两个保持核的复合不必在联合空间仍可逆，此处不把复合的不变性误说成自动详细平衡。

若提议不保持体积，接受比还需 Jacobian 因子；状态依赖地改变步数或步长，也须重新核对反向提议。实现中的有限精度可逆误差不是上述精确算术证明的一部分。接受校正不保证独立样本或快速混合：步长过大导致拒绝，轨迹过短导致高相关，质量矩阵失配使不同方向移动不平衡。采样以保持分布为目标，不要求能量一路下降，所以不能将 Hamilton 轨迹解释为更快的梯度下降。

结论	所比较的对象	尚未得到的保证
强数值误差小	同一驱动下数值状态与真状态	长期抽样偏差小
弱数值误差小	两种状态分布的测试函数期望	单条路径距离小
密度 π 不变	从 π 出发仍保持 π	其他初态快速趋于 π
概率流匹配边缘	每个时刻的状态分布	相同时间联合规律

表 13.2 随机演化中几种保证的对象。每一项均依赖相应小节给出的光滑性、边界或数值条件，不能用一个对象上的结论替代另一个对象上的结论。

13.5 随机状态的观测与推断

过程噪声规定真实状态如何随机移动；传感器读数则提供关于这条未知轨迹的证据。因此推断不是再次生成一条任意轨迹，而是在已给定的生成模型中，根据各个候选状态产生这组读数的可能性，重新分配状态概率。为此要明确我们拿到了哪些读数、想估计哪个时刻的状态，再分别推导预测、滤波和平滑的计算公式。

13.5.1 状态观测与推断目标

在前面的状态转移 K_t 之外增加观测核 $G_t(\mathbf{x}, B) = \mathbb{P}(\mathbf{y}_t \in B \mid \mathbf{x}_t = \mathbf{x})$ 。它表示状态为 $\mathbf{x}$ 时传感器返回哪些读数。线性加性例为

$$\mathbf{y}_t = \mathbf{C}_t \mathbf{x}_t + \mathbf{v}_t. \quad (13.67)$$

先假设初值、所有过程噪声与所有观测噪声相互独立，输入与矩阵给定。于是给定 $\mathbf{x}_t$ 后， $\mathbf{y}_t$ 不再依赖旧状态和旧观测；给定当前状态后，下一状态由 K_t 生成。联合规律在式 (13.29) 的基础上分解为

$$\pi_0(d\mathbf{x}_0) \prod_{t=0}^{T-1} K_t(\mathbf{x}_t, d\mathbf{x}_{t+1}) \prod_{t=1}^T G_t(\mathbf{x}_t, d\mathbf{y}_t).$$

这里从 $\mathbf{y}_1$ 开始观察， π_0 不含一个未声明的 $\mathbf{y}_0$ 。若噪声相关、传感器依赖旧状态或有内部滞后，须扩充联合状态或显式改写这些条件关系。观测序列通常不满足自身的 Markov 性，因为一次带噪读数未必概括隐藏状态。

记 $\mathbf{y}_t = \sigma(\mathbf{y}_1, \dots, \mathbf{y}_t)$ ， $\mathbf{y}_0$ 为无观测信息。欧氏状态与观测具有正则条件分布，使“给定这段读数的状态概率”能作为概率核处理。即使观测无噪，也不一定足够： $\mathbf{y}_t = \mathbf{x}_{1,t} + \mathbf{x}_{2,t}$ 不能区分 $(1, 0)^\top$ 与 $(0, 1)^\top$ 。能否借后续动力学区分这些方向，需要第 14 章的可观测性与可检测性条件。

示例 13.33 带泄漏温度的间接观测 回到同一模型 $x_{t+1} = 0.8x_t + u_t + w_{t+1}$ 、 $y_t = x_t + v_t$ ，其中 $w_t \sim \mathcal{N}(0, 0.04)$ 、 $v_t \sim \mathcal{N}(0, 0.09)$ ，与初值及彼此独立。即使传感器完全精确，未来仍因 w_{t+1} 不确定；即使过程无噪，当前状态也可能因读数噪声而不确定。图 13.4 的轨迹从已知 $x_0 = 0$ 出发，使用给定 $u_t = 0.4$ ；后面的估计继续使用该初值与同一组读数，不另换一条更利于展示的状态轨迹。

得到条件分布后，还须规定输出什么估计。平方损失下，若 $\mathbf{X}$ 二阶可积，对信息 $\mathcal{G}$ 可测的估计 $\mathbf{a}$ ，

$$\mathbb{E}[\|\mathbf{X} - \mathbf{a}\|^2 | \mathcal{G}] = \mathbb{E}[\|\mathbf{X} - \mathbb{E}(\mathbf{X} | \mathcal{G})\|^2 | \mathcal{G}] + \|\mathbb{E}(\mathbf{X} | \mathcal{G}) - \mathbf{a}\|^2.$$

交叉项因条件均值为零而消失，所以条件均值最小化均方损失。离散状态的零一损失选条件众数；连续密度的 MAP 是另一种点输出，不能不说明损失就把所有“最优估计”视为同义。

13.5.2 不同观测范围下的边缘状态推断

固定目标时刻 t ，改变可用观测的终点 j 。记 $\mathbf{m}_{t|j} = \mathbb{E}[\mathbf{x}_t | \mathcal{Y}_j]$ 、 $\mathbf{P}_{t|j} = \text{Cov}(\mathbf{x}_t | \mathcal{Y}_j)$ 。三种查询的区别先由信息范围决定，与使用哪一种算法无关。

下面的一般核公式只要求前述条件独立结构。需要解析闭合时，再采用有限时域线性高斯条件：

$$\mathbf{x}_0 \sim \mathcal{N}(\mathbf{m}_{0|0}, \mathbf{P}_{0|0}), \quad \mathbf{w}_{t+1} \sim \mathcal{N}(\mathbf{0}, \mathbf{Q}_{t+1}), \quad \mathbf{v}_t \sim \mathcal{N}(\mathbf{0}, \mathbf{R}_t).$$

查询	目标条件分布	允许的观测
一步预测	$P(\mathbf{x}_t \mathbf{y}_{t-1})$	新读数以前
当前滤波	$P(\mathbf{x}_t \mathbf{y}_t)$	包括当前读数
固定区间平滑	$P(\mathbf{x}_t \mathbf{y}_T), T > t$	包括事后未来读数

表 13.3 同一目标状态的三种边缘查询。信息终点改变，物理状态并未改变；平滑使用的未来读数不能用于当时的在线行动。

三组随机量彼此独立，系统矩阵与输入确定， $\mathbf{P}_{0|0}, \mathbf{Q}_{t+1} \geq \mathbf{0}$ ，先取 $\mathbf{R}_t > \mathbf{0}$ 。本章统一让 w_{t+1} 与它推动到达的状态时刻一致；因此从 $t-1$ 到 t 的过程协方差写为 $\mathbf{Q}_t$ 。这些条件在每个有限 T 内使用，不预设滤波增益已达稳态。

13.5.2.1 过去观测下的状态预测

若已有截至 $t-1$ 的条件分布 π_{t-1} ，全概率公式给出

$$\pi_{t|t-1}(A) = \int K_{t-1}(\mathbf{x}, A) \pi_{t-1}(d\mathbf{x}). \quad (13.68)$$

这是把每个候选旧状态的下一步分布，按其当前可信程度混合。多步预测重复施加转移核，中途没有新观测便没有似然校正。

例如隐藏状态为 $\{0, 1\}$ ， $\pi_0 = (0.7, 0.3)$ ，按当前状态为行、下一状态为列的转移矩阵为 $\mathbf{P} = \begin{bmatrix} 0.8 & 0.2 \\ 0.1 & 0.9 \end{bmatrix}$ 。于是 $\pi_{1|0}(1) = 0.7(0.2) + 0.3(0.9) = 0.41$ ， $\pi_{1|0}(0) = 0.59$ 。这是尚未看 y_1 的结果；下一小节再用同一预测做校正。

在线性高斯条件下，仿射变换与独立高斯相加保持高斯性，所以

$$\mathbf{m}_{t|t-1} = \mathbf{A}_{t-1} \mathbf{m}_{t-1|t-1} + \mathbf{B}_{t-1} \mathbf{u}_{t-1}, \quad (13.69)$$

$$\mathbf{P}_{t|t-1} = \mathbf{A}_{t-1} \mathbf{P}_{t-1|t-1} \mathbf{A}_{t-1}^\top + \mathbf{Q}_t. \quad (13.70)$$

温度第一步为 $m_{1|0} = 0.4, P_{1|0} = 0.04$ ：初值已知并不等于未来状态已知。一般预测方差并非必然大于旧方差，因为 $\mathbf{A}$ 可能收缩；过程噪声是在已传播的协方差之上增加 $\mathbf{Q}_t$ 。若 w_t 与旧状态相关，须增加 $\mathbf{A}_{t-1} \text{Cov}(\mathbf{x}_{t-1}, \mathbf{w}_t | \mathbf{y}_{t-1})$ 及其转置，并使用噪声的条件均值和条件协方差。未经核对独立性就删交叉项，会改变预测。

13.5.2.2 当前及过去观测下的状态滤波

定义 13.34 滤波分布 当前状态在截至当前的观测信息下的条件概率核

$$\pi_t(A) = \mathbb{P}(\mathbf{x}_t \in A \mid \mathbf{y}_t) \quad (13.71)$$

称为滤波分布。滤波分布描述我们对真实状态 $\mathbf{x}_t$ 的判断；真实状态是要估计的对象，实际读数 $\mathbf{y}_t$ 则是作出判断的依据。

若观测核有相对于共同 σ 有限测度 ν_t 的联合可测密度 $G_t(\mathbf{x}, d\mathbf{y}) = g_t(\mathbf{y} \mid \mathbf{x})\nu_t(d\mathbf{y})$ ，则 Bayes 公式给出

$$\pi_t(d\mathbf{x}) = \frac{g_t(\mathbf{y}_t \mid \mathbf{x})\pi_{t|t-1}(d\mathbf{x})}{\int g_t(\mathbf{y}_t \mid \mathbf{z})\pi_{t|t-1}(d\mathbf{z})}. \quad (13.72)$$

分母必须有限且严格为正。共同支配测度不依赖候选状态，才能把这些似然放在同一尺度比较；没有这种密度表示时仍有正则条件分布，但不能生搬该比值。

示例 13.35 两状态模型的一次预测与校正 接续上一小节的预测结果。若 $\mathbb{P}(y_1 = 1 \mid x_1 = 0) = 0.2$ 、 $\mathbb{P}(y_1 = 1 \mid x_1 = 1) = 0.8$ ，实际看到 $y_1 = 1$ 后，

$$\pi_1(1) = \frac{0.8(0.41)}{0.2(0.59) + 0.8(0.41)} = \frac{164}{223} \approx 0.735.$$

新读数更可能由状态 1 产生，因此它的后验概率从 0.41 升到约 0.735。这一步只需预测分布与新读数的似然。一般递推中，上一时刻的滤波分布已经汇总了旧观测对状态的影响，所以可以从它继续预测、校正，而不必重新处理全部读数。

在线性高斯模型中，上面的密度乘积可以用一次联合高斯条件化完成。给定 $\mathbf{y}_{t-1}$ ，

$$\begin{bmatrix} \mathbf{x}_t \\ \mathbf{y}_t \end{bmatrix} \sim \mathcal{N} \left(\begin{bmatrix} \mathbf{m}_{t|t-1} \\ \mathbf{C}_t \mathbf{m}_{t|t-1} \end{bmatrix}, \begin{bmatrix} \mathbf{P}_{t|t-1} & \mathbf{P}_{t|t-1} \mathbf{C}_t^\top \\ \mathbf{C}_t \mathbf{P}_{t|t-1} & \mathbf{S}_t \end{bmatrix} \right), \quad (13.73)$$

实际读数与旧观测所预测的读数之差 $\mathbf{r}_t = \mathbf{y}_t - \mathbf{C}_t \mathbf{m}_{t|t-1}$ 称为创新。它记录这次读数中未被预测的偏差，其创新协方差为

$$\mathbf{S}_t = \mathbf{C}_t \mathbf{P}_{t|t-1} \mathbf{C}_t^\top + \mathbf{R}_t. \quad (13.74)$$

$R_t > \mathbf{0}$ 保证 S_t 可逆。由条件高斯公式,

$$\mathbf{K}_t = \mathbf{P}_{t|t-1} \mathbf{C}_t^\top \mathbf{S}_t^{-1}, \quad (13.75)$$

$$\mathbf{m}_{t|t} = \mathbf{m}_{t|t-1} + \mathbf{K}_t \mathbf{r}_t, \quad (13.76)$$

$$\mathbf{P}_{t|t} = \mathbf{P}_{t|t-1} - \mathbf{K}_t \mathbf{S}_t \mathbf{K}_t^\top. \quad (13.77)$$

Kalman 增益 $\mathbf{K}_t$ 把读数与预测之间的差换算成状态均值的校正量。它根据预测状态误差与观测噪声的协方差计算, 决定这次校正应多大。减去的是半正定项, 所以这次高斯校正不增加条件协方差。一般非高斯模型中, “更多信息减少均方误差” 是平均意义的结论, 不保证每个罕见读数对应的后验方差都比先验小。⁸

定理 13.36 有限时域 Kalman 滤波 在上述独立线性高斯模型与创新协方差可逆条件下, 预测与校正公式精确给出 $\mathbf{x}_t | \mathbf{y}_t \sim \mathcal{N}(\mathbf{m}_{t|t}, \mathbf{P}_{t|t})$, 对每个有限 t 成立。

证明. $t = 0$ 时无观测, 条件分布就是给定高斯初值。假设上一时刻结论成立, 独立高斯过程噪声与线性状态更新得到式 (13.69) 和 (13.70), 并保持高斯性。独立高斯观测噪声又给出式 (13.73)。为核对条件化, 令 $\mathbf{e} = \mathbf{x}_t - \mathbf{m}_{t|t-1} - \mathbf{K}_t \mathbf{r}_t$ 。在 $\mathbf{y}_{t-1}$ 条件下, $\text{Cov}(\mathbf{e}, \mathbf{r}_t) = \mathbf{P}_{t|t-1} \mathbf{C}_t^\top - \mathbf{K}_t \mathbf{S}_t = \mathbf{0}$ 。联合高斯中不相关即独立, 所以给定新读数后 $\mathbf{e}$ 仍为零均值高斯, 协方差为 $\mathbf{P}_{t|t-1} - \mathbf{K}_t \mathbf{S}_t \mathbf{K}_t^\top$ 。新条件均值与协方差正是上述校正式, 归纳完成。 ■

把估计误差写成 $(\mathbf{I} - \mathbf{K}_t \mathbf{C}_t)(\mathbf{x}_t - \mathbf{m}_{t|t-1}) - \mathbf{K}_t \mathbf{v}_t$, 利用两项误差独立, 得到 Joseph 形式

$$\mathbf{P}_{t|t} = (\mathbf{I} - \mathbf{K}_t \mathbf{C}_t) \mathbf{P}_{t|t-1} (\mathbf{I} - \mathbf{K}_t \mathbf{C}_t)^\top + \mathbf{K}_t \mathbf{R}_t \mathbf{K}_t^\top. \quad (13.78)$$

展开并用 $\mathbf{K}_t \mathbf{S}_t = \mathbf{P}_{t|t-1} \mathbf{C}_t^\top$, 即恢复简化校正式。半正定项相加的形式更利于有限精度下维持协方差性质; 实现应解线性方程求增益作用, 不显式形成 $\mathbf{S}_t^{-1}$ 。

示例 13.37 标量观测怎样权衡预测与读数 对 $y = x + v$, $v \sim \mathcal{N}(0, r)$, 用 m^-, p^- 表示新读数到达前的预测均值与方差, 用 m^+, p^+ 表示校正后的均值与方差。于是有 $K = p^- / (p^- + r)$, $m^+ = m^- + K(y - m^-)$, $p^+ = p^- r / (p^- + r)$ 。为便于直接查看权重, 先用一组简单的教学数值 $(m^-, p^-, r, y) = (0, 4, 1, 2)$, 得到 $K = 4/5$, $m^+ = 8/5$, $p^+ = 4/5$ 。再把同一公式用于贯穿温度模型。此时仍用 $r = 0.09$, 第一步增益为 $0.04/0.13 = 4/13$, $m_{1|1} = 0.4 + \frac{4}{13}(y_1 - 0.4)$, $P_{1|1} = 0.036/1.3 \approx 0.02769$ 。手算例中的预测比读数更不确定, 所以均值向读数移动了差值的 $4/5$;

⁸ R. E. Kalman, *A New Approach to Linear Filtering and Prediction Problems* In *Journal of Basic Engineering*, 1960, vol. 82, no. 1, pp. 35–45

温度第一步的预测更精确，校正只采用差值的 4/13。差别来自两例各自的噪声方差。

观测越精确，直接观测方向的增益通常越大；未被 $\mathbf{C}_t$ 区分的方向可能仍有不确定性。图 13.7 显示标量分布如何重加权：密度变高表示质量集中，不是单点概率大于 1。




图 13.7 独立标量教学例的预测 $\mathcal{N}(0, 4)$ 与后验 $\mathcal{N}(1.6, 0.8)$ ，实际读数 $y = 2$ 、观测噪声方差 1。第二个高斯参数是方差；本图不是贯穿温度模型的参数设定。

若状态更新为 $\mathbf{x}_{t+1} = \mathbf{f}_t(\mathbf{x}_t) + \mathbf{w}_{t+1}$ ，观测为 $\mathbf{y}_t = \mathbf{h}_t(\mathbf{x}_t) + \mathbf{v}_t$ ，我们仍要根据截至当前的读数估计当前状态，但非线性变换一般使预测与后验不再保持高斯形式。为了继续用均值和协方差递推，扩展 Kalman 滤波（EKF）把更新函数在滤波均值附近近似为线性函数，以 $\mathbf{F}_t = D\mathbf{f}_t(\mathbf{m}_{t|t})$ 传播协方差，预测均值取 $\mathbf{f}_t(\mathbf{m}_{t|t})$ ；在预测均值处以 $\mathbf{H}_{t+1} = D\mathbf{h}_{t+1}(\mathbf{m}_{t+1|t})$ 构造创新协方差和增益。它把局部函数替换为一阶线性函数，所以通常既忽略曲率对均值的影响，也把后验压回单个高斯。

无迹 Kalman 滤波（UKF）则用一组确定性 sigma 点代表当前均值与协方差，把这些点送入原非线性函数，再从输出点估计新的均值与协方差。例如对 d 维均值 $\mathbf{m}$ 与协方差 $\mathbf{P} = \mathbf{L}\mathbf{L}^\top$ ，取 $\kappa \geq 0$ ，点为 $\mathbf{m}$ 及 $\mathbf{m} \pm \sqrt{d + \kappa}\mathbf{L}_i$ ，权重分别为 $\kappa/(d + \kappa)$ 与 $1/[2(d + \kappa)]$ 。它们精确匹配原均值与协方差。将点代入 $\mathbf{f}$ ，以加权和、加权外积估计新均值与协方差，再给协方差加上过程噪声 $\mathbf{Q}$ 。本处采用重新生成点的实现：依据加入 $\mathbf{Q}$ 后的预测均值和协方差重新构造 sigma 点，再把这组点送入 $\mathbf{h}$ ，计算预测观测均值、观测协方差及状态观测交叉协方差。观测协方差还须加上观测噪声 $\mathbf{R}$ ，随后按 Kalman 的创新与增益公式校正。重新生成点使观测预测也包含本步新增的过程不确定性。例如标量线性系统 $f(x) = h(x) = x$ ，旧状态方差 $p = 1$ ，过程与观测噪声方差 $q = r = 1$ ，上述步骤给出预测方差 2、创新方差 3、交叉方

差 2, 故增益为 $2/3$, 与精确 Kalman 公式一致; 直接复用未包含 q 的原传播点则无法得到这个结果。这是简单的非负权重构造, 实际 UKF 还可使用带缩放参数的不同权重。UKF 近似计算均值与协方差, 再用一个高斯分布概括后验; 非线性模型本身并没有因此变为精确的线性模型。

两种方法都可能遗漏多峰后验。例如零均值对称先验配上 $y = x^2 + v$, 一个明显正的读数可能支持正负两个状态区间。EKF 在 $x = 0$ 的观测导数为零; 对称 sigma 点也有零状态观测交叉协方差, 单高斯校正不能表达分裂成两峰的证据。粒子滤波改用加权经验分布 $\sum_i \omega_t^{(i)} \delta_{x_t^{(i)}}$: 从已有粒子按转移核抽下一状态, 将权重乘当前似然再归一化, 必要时按权重重采样。其近似对象是整个滤波概率测度, 并用有限样本替代核积分; 权重集中、高维与重采样损失多样性仍是限制。高斯混合则保留多个分量, 分别传播和校正, 再用似然更新分量权重; 分量合并或剪枝会引入另一种近似。

13.5.2.3 有限时域完整观测下的状态平滑

固定终点 T 后, 未来读数也能帮助判断旧状态。关键不是再向前预测, 而是把新获得的下一状态分布通过反向条件关系传回去。在线性高斯条件下, 给定 y_t ,

$$\begin{bmatrix} \mathbf{x}_t \\ \mathbf{x}_{t+1} \end{bmatrix} \sim \mathcal{N} \left(\begin{bmatrix} \mathbf{m}_{t|t} \\ \mathbf{m}_{t+1|t} \end{bmatrix}, \begin{bmatrix} \mathbf{P}_{t|t} & \mathbf{P}_{t|t} \mathbf{A}_t^\top \\ \mathbf{A}_t \mathbf{P}_{t|t} & \mathbf{P}_{t+1|t} \end{bmatrix} \right).$$

若 $\mathbf{P}_{t+1|t}$ 可逆, 条件高斯公式给出

$$\mathbf{J}_t = \mathbf{P}_{t|t} \mathbf{A}_t^\top \mathbf{P}_{t+1|t}^{-1}, \quad (13.79)$$

$$\mathbb{E}[\mathbf{x}_t | \mathbf{x}_{t+1}, y_t] = \mathbf{m}_{t|t} + \mathbf{J}_t (\mathbf{x}_{t+1} - \mathbf{m}_{t+1|t}), \quad (13.80)$$

$$\text{Cov}(\mathbf{x}_t | \mathbf{x}_{t+1}, y_t) = \mathbf{P}_{t|t} - \mathbf{J}_t \mathbf{P}_{t+1|t} \mathbf{J}_t^\top. \quad (13.81)$$

这里的 $\mathbf{J}_t$ 关联相邻状态, 不是由当前传感器直接得到的 Kalman 增益。

定理 13.38 有限时域 RTS 平滑 在有限时域 Kalman 条件及每个 $\mathbf{P}_{t+1|t}$ 可逆条件下, 从终点 $(\mathbf{m}_{T|T}, \mathbf{P}_{T|T})$ 向后递推

$$\mathbf{m}_{t|T} = \mathbf{m}_{t|t} + \mathbf{J}_t (\mathbf{m}_{t+1|T} - \mathbf{m}_{t+1|t}), \quad (13.82)$$

$$\mathbf{P}_{t|T} = \mathbf{P}_{t|t} + \mathbf{J}_t (\mathbf{P}_{t+1|T} - \mathbf{P}_{t+1|t}) \mathbf{J}_t^\top, \quad (13.83)$$

精确给出 $\mathbf{x}_t | y_T$ 的高斯均值与协方差。

证明. 给定 $\mathbf{x}_{t+1}$ 后, 未来状态和观测与更早状态条件独立, 因此 $P(\mathrm{d}\mathbf{x}_t | \mathbf{x}_{t+1}, \mathbf{y}_T) = P(\mathrm{d}\mathbf{x}_t | \mathbf{x}_{t+1}, \mathbf{y}_t)$ 。全概率公式给出后向因子化

$$P(\mathrm{d}\mathbf{x}_t | \mathbf{y}_T) = \int P(\mathrm{d}\mathbf{x}_t | \mathbf{x}_{t+1}, \mathbf{y}_t) P(\mathrm{d}\mathbf{x}_{t+1} | \mathbf{y}_T). \quad (13.84)$$

将一步条件均值对 $\mathbf{x}_{t+1} | \mathbf{y}_T$ 取期望, 塔式性质得到平滑均值公式。全协方差公式分成两项: 条件内协方差为 $\mathbf{P}_{t|t} - \mathbf{J}_t \mathbf{P}_{t+1|t} \mathbf{J}_t^\top$, 条件均值的协方差为 $\mathbf{J}_t \mathbf{P}_{t+1|t} \mathbf{J}_t^\top$; 相加即得平滑协方差。一步条件核的均值为仿射函数、协方差不依赖下一状态, 与高斯下一状态混合仍为高斯。从 T 向后归纳, 完成全部时刻的结论。 ■

前向保存每步滤波与预测的均值、协方差, 后向依次计算 $\mathbf{J}_t$ 及上述两式, 就是 Rauch–Tung–Striebel (RTS) 平滑算法。⁹ 未来观测影响过去的条件分布, 不改变已经发生的物理状态。

⁹ H. E. Rauch, F. Tung, C. T. Striebel, *Maximum Likelihood Estimates of Linear Dynamic Systems* In AIAA Journal, 1965, vol. 3, no. 8, pp. 1445–1450

示例 13.39 未来观测降低过去状态的不确定性 为了手算一次后向校正, 暂把状态更新中的衰减系数取为 1, 得到随机游走 $x_1 = x_0 + w_1$, 观测仍为 $y_1 = x_1 + v_1$ 。取 $m_{0|0} = 0, P_{0|0} = 1, Q_1 = 1, R_1 = 2/3$ 且噪声独立。观察 $y_1 = 2$ 后, $m_{1|0} = 0, P_{1|0} = 2, K_1 = 3/4, m_{1|1} = 3/2, P_{1|1} = 1/2$ 。于是 $J_0 = 1/2, m_{0|1} = 3/4, P_{0|1} = 1 + \frac{1}{4}(\frac{1}{2} - 2) = 5/8$ 。在时刻 0 尚不能使用这个结果; 此时只有均值 0、方差 1 的初始先验。

图中的高斯平滑协方差不超过相应滤波协方差, 但某一条实现上的均值误差未必每个时刻都更小。条件均方误差的保证与某一次噪声实现上的误差是不同对象。若预测协方差奇异, 须在其仿射支持上条件化, 广义逆只是计算工具, 还要检查条件状态是否属于支持, 不能只替换逆号。非线性近似平滑可沿相同后向关系用局部线性化或 sigma 点估计相邻状态的交叉矩; 粒子平滑则近似反向核或路径权重。无论采用哪种表示, 使用 $\mathbf{y}_T$ 这一信息条件都不改变。

13.5.3 完整观测下的联合轨迹推断

各时刻边缘分布回答“那一刻可能在哪里”, 整条路径后验还要回答“这些状态如何一起出现”。在共同观测密度条件下,

$$P(\mathrm{d}\mathbf{x}_{0:T} | \mathbf{y}_{1:T}) = \frac{1}{Z(\mathbf{y}_{1:T})} \pi_0(\mathrm{d}\mathbf{x}_0) \prod_{t=0}^{T-1} K_t(\mathbf{x}_t, \mathrm{d}\mathbf{x}_{t+1}) \prod_{t=1}^T g_t(\mathbf{y}_t | \mathbf{x}_t), \quad (13.85)$$

其中证据 Z 是分子对路径的积分, 要求 $0 < Z < \infty$ 。乘积记号按转移核的迭代积分理解, 不预设状态本身有 Lebesgue 密度。每个平滑边缘由这一个联合后验积分而来; 反过来, 只给全部边缘并不能恢复跨时刻关联。




图 13.8 与图 13.4 完全相同的温度轨迹及读数。三栏分别画一步预测、滤波与固定终点 $T = 24$ 的平滑均值和逐时刻 95% 高斯区间, 灰线为实际状态, 圆点为读数; 区间不是整条路径同时覆盖的置信带。下方以 $t = 12$ 为例标出可用观测范围。已知 $x_0 = 0$, 给定 $u_t = 0.4$, 过程、观测方差仍为 0.04, 0.09。平滑的信息优势不是额外的在线能力。

若损失为 $\sum_t \|x_t - a_t\|^2$ ，联合条件均值的各分量就是 $m_{t|T}$ ，因此逐时刻平滑均值同时组成最小化该可加平方损失的路径输出。在线性高斯模型中，把所有状态堆叠为 $\mathbf{X}$ 后，后验仍为联合高斯。协方差 $\Sigma > \mathbf{0}$ 时，其密度正比于 $\exp[-(\mathbf{X} - \mathbf{m})^\top \Sigma^{-1}(\mathbf{X} - \mathbf{m})/2]$ ，故联合众数为 $\mathbf{m}$ ，也与各时刻的边缘众数一致。这是一项高斯结构结论，不是所有后验的性质。

若 Σ 奇异，后验集中在仿射支持 $\mathbf{m} + \text{range}(\Sigma)$ ，没有全维 Lebesgue 密度。对 $\Sigma = \mathbf{U}_r \Lambda_r \mathbf{U}_r^\top$ ，在支持坐标 $\mathbf{z} = \mathbf{U}_r^\top(\mathbf{X} - \mathbf{m})$ 中才有非退化高斯密度；其唯一众数为 $\mathbf{z} = \mathbf{0}$ ，对应 $\mathbf{m}$ 。条件高斯使用广义逆时也必须要求所给证据位于其支持内；支持外的条件值属于零概率事件，公式不能赋予一个未经指定的后验意义。

非高斯下可直接看出区别。设两个时刻的联合后验为

$$P(x_0 = 0, x_1 = 0) = 0.40,$$

$$P(x_0 = 0, x_1 = 1) = 0.25,$$

$$P(x_0 = 1, x_1 = 1) = 0.35.$$

其他组合概率为零。它可由初始概率 (0.65, 0.35) 和转移 $P_{00} = 8/13, P_{01} = 5/13, P_{11} = 1$ 生成，再配无信息观测。时刻 0 的边缘众数为 0，时刻 1 的边缘众数为 1；拼接得到 (0, 1)，联合概率只有 0.25，低于联合最优路径 (0, 0) 的 0.40。在每个时刻分别选最可能的状态，可能错过联合概率最大的整条路径。

有限状态的联合 MAP 可沿链做最大乘积或 Viterbi 递推，而边缘查询沿链求和；其局部函数计算回见第 9 章。连续非高斯模型可能用路径优化求一个 MAP，也可能用粒子或 Monte Carlo 方法近似整个后验；前者不是后者的替代品。例如由 $\mathbf{x}_T | \mathbf{y}_T$ 抽样，再逐步按反向条件核抽 $\mathbf{x}_t | \mathbf{x}_{t+1}, \mathbf{y}_t$ ，得到的是有关联的后验路径；独立从每个平滑边缘抽样会丢掉这些关联。

本节的精确结论都在有限时域成立。稳态增益、极限协方差及估计误差的长期稳定性，仍需可检测性、噪声作用方向等系统条件；这些问题交由第 14 章处理。在那里输入才由反馈主动选择，本章一直把 $\mathbf{u}_t$ 当作已给定量。

13.6 本章小结

状态保存过去对未来仍有用的作用，输入规定外部行动，初值选定演化的起点。离散更新通过有序复合得到轨迹；连续更新须先证明积分方程有解，局部唯一性与无爆炸延拓各有条件。线性传播把初值与历史输入分开，有限维投影则只保存选定的历史坐标，不天然保留全部信息。

计算轨迹还要选择近似对象。Euler 与 Runge-Kutta 近似连续流，零阶保持精确对应区间内恒定输入，蛙跳利用 Hamilton 几何；仿射扫描改变

求值括号而不改变时间次序。有限时域误差小、辛结构保持、长期稳定不是同一种保证。谱和 Lyapunov 函数描述扰动的长期行为，非正规耦合则提醒我们：最终衰减仍可能伴随显著的中间放大。

过程噪声把确定轨迹变为联合随机规律。随机逼近的平均 ODE 须配合步长、噪声与有界性条件；连续 Brownian 积分保留二次变差，有限活动跳跃按事件前信息累计。Itô 公式据此计算函数变化，SDE 再把系数与未知状态连接起来。矩与 Fokker-Planck 方程分别描述摘要和边缘演化，不能单独取代联合路径规律。有限轨迹模拟、Langevin 不变性与 HMC 接受校正也各自回答不同的计算问题。

观测不改变过去真实状态，却改变我们对它的条件分布。预测、滤波和平滑依次使用更长的观测范围；在线性高斯条件下，Kalman 与 RTS 精确完成这些有限时域查询。非线性近似须说明是在近似函数、矩还是整个概率测度，联合路径最优也不能用一般的边缘众数拼接代替。回到章首的温度问题，模型和噪声决定房间怎样变化，计算方法给出轨迹或分布的近似，观测帮助我们估计未知状态，损失则规定什么估计更符合任务要求。下一章再让输入依据当前信息选择，研究怎样主动改变轨迹。

策略的实现与轨迹控制

给温度系统一个固定加热量，可以算出它以后有多热；要让温度保持在指定值，却必须反过来选择加热量。第 13 章已经建立给定行动下的状态演化、稳定性和状态估计。本章把行动改为待设计的对象：控制器依据当前可用信息，不断纠正状态与目标之间的偏差。这样的反馈（feedback）会改变系统的演化规律，因而必须对新的闭环轨迹重新作出判断。

本章沿用温度教学模型

$$x_{t+1} = 0.8x_t + u_t + w_{t+1}, \quad y_t = x_t + v_t, \quad (14.1)$$

其中 x_t 是相对于环境温度的温差， u_t 是归一化加热量， y_t 是传感器读数。除明确讨论随机扰动的段落外，先取 $w_{t+1} = v_t = 0$ ，并允许任意实数输入。需要随机例子时，采用相互独立的 $w_t \sim \mathcal{N}(0, 0.04)$ 、 $v_t \sim \mathcal{N}(0, 0.09)$ ，两族噪声也相互独立并独立于初态；需要硬安全约束时再明确改用无噪声或有界扰动，而不把高斯噪声当成有界扰动。状态时间均以下标表示，策略学习若有更新轮次则用带括号上标，与系统时间区分。

让状态到达目标、逐渐接近目标、跟随运动参考，以及在全过程中不越界，是四种不同要求。输入可能无法改变某些状态方向，传感器也可能无法辨认某些误差。结构能力决定哪些目标有可能实现，稳定反馈决定偏差如何消退；目标改为非零设定值或运动轨迹时，还要补入维持目标所需的输入。安全约束则进一步筛去可能越界的动作。本章据此设计能够实际执行的策略，并判断它们能保证哪些轨迹性质；第 15 章再系统比较策略的累计价值。本章保留二次成本这一可以直接构造反馈的特例，但不把“能实现目标”与“价值最优”混为一谈。

14.1 策略的实现与可达轨迹

选择反馈前，需要弄清控制器拿得到什么信息，以及输入实际能改变哪些方向。例如，目标可能要求执行器无法提供的加热量；不同内部状态也可

能产生相同的传感器读数。下面分别检查动作的可实现性与状态的可区分性。

14.1.1.1 开环策略与反馈策略

考虑离散时间线性时不变系统

$$\begin{aligned} \mathbf{x}_{t+1} &= \mathbf{A}\mathbf{x}_t + \mathbf{B}\mathbf{u}_t, \\ \mathbf{y}_t &= \mathbf{C}\mathbf{x}_t, \end{aligned} \quad (14.2)$$

其中 $\mathbf{x}_t \in \mathbb{R}^n$ 、 $\mathbf{u}_t \in \mathbb{R}^m$ 和 $\mathbf{y}_t \in \mathbb{R}^p$ 分别是状态、输入和输出； $\mathbf{A}, \mathbf{B}, \mathbf{C}$ 的维度依次为 $n \times n, n \times m, p \times n$ 。这里取直接传递矩阵为零：时刻 t 的状态先产生读数，控制器再计算 $\mathbf{u}_t$ ，输入随后推动系统到 $t+1$ 。若使用 $\mathbf{y}_t = \mathbf{C}\mathbf{x}_t + \mathbf{D}\mathbf{u}_t$ ，又让当前动作依赖当前读数，两式便形成代数环，必须证明联立方程有唯一解；只使用截至 $t-1$ 的读数是另一种无环约定。

策略 (policy) 是一套从允许信息到动作的规则；预先给定动作的规则与随读数修正动作的规则，区别在于能否使用运行中新获得的信息。

定义 14.1 开环控制与反馈控制 若输入序列 $\mathbf{u}_0, \mathbf{u}_1, \dots$ 事先指定，不根据运行中实际出现的状态修正，称为开环控制 (open-loop control)。状态可直接取得时，规则

$$\mathbf{u}_t = \kappa_t(\mathbf{x}_t)$$

称为状态反馈 (state feedback)。仅有观测和已执行动作可用时，规则

$$\mathbf{u}_t = \mu_t(\mathbf{y}_0, \dots, \mathbf{y}_t; \mathbf{u}_0, \dots, \mathbf{u}_{t-1})$$

称为输出反馈 (output feedback)，在初始时刻，尚未执行任何控制动作，控制历史为空。随机系统中，动作必须对这些允许信息可测，不能使用尚未产生的噪声。

在温度例中，始终取 $u_t = 0.4$ 是一条开环策略；若直接测得状态，则可以根据 $x_t - 2$ 修正输入。若只有带噪声的 y_t ，把 x_t 写进控制公式并不会使真实状态变得可用，必须说明怎样从读数构造估计。本章的输出反馈会使用 y_0 。因此，初始先验描述看到 y_0 前的状态判断，利用 y_0 校正后才得到后验；计算时需要区分这两者。

反馈与原动态合成新的闭环系统，还需核对适定性，即给定初态后能否唯一生成轨迹。离散递推要求每一步反馈有定义并产生允许动作；连续系统通常要求闭环右端局部 Lipschitz，并另查解是否存在到所需时域。切换

反馈若不连续，需要合适的不连续微分方程解概念，不能只写闭环方程就断言唯一性。

14.1.2 目标状态的可达与可控

给定输入序列以后，连续展开式 (14.2) 的前 N 步得到

$$\mathbf{x}_N = \mathbf{A}^N \mathbf{x}_0 + \sum_{t=0}^{N-1} \mathbf{A}^{N-1-t} \mathbf{B} \mathbf{u}_t. \quad (14.3)$$

固定初态时，输入引起的终态变化属于 $\text{col}[\mathbf{B}, \mathbf{A}\mathbf{B}, \dots, \mathbf{A}^{N-1}\mathbf{B}]$ 。这些列表示输入经过不同步数的传播后能够产生的状态方向；它们张成的空间就是相应时域的可达子空间 (reachable subspace)。

定义 14.2 可控性 对式 (14.2)，若任意初态 $\mathbf{x}_0$ 和任意目标 $\mathbf{x}_f$ 之间都存在有限时刻 N 及无幅值限制的输入序列，使 $\mathbf{x}_N = \mathbf{x}_f$ ，称 $(\mathbf{A}, \mathbf{B})$ 可控 (controllable)。

一次到达某个目标只要求式 (14.3) 对该目标可解；可控性要求任意初态和任意目标之间均可解。在线性时不变系统中，从零到任意终态与上述定义等价，因为自由响应可以移到目标一侧。它们都蕴含任意初态可在有限时间驱动到零，但这个较弱的零可控性 (null controllability) 一般不能反推可控性： $\mathbf{A} = \mathbf{B} = 0$ 会在一步后把任意初态变成零，却无法从零到达非零状态。当 $\mathbf{A}$ 可逆时，零可控性才能反推出这里的可控性。

定理 14.3 Kalman 可控性秩判据 定义可控性矩阵

$$\mathcal{C}(\mathbf{A}, \mathbf{B}) = [\mathbf{B} \ \mathbf{A}\mathbf{B} \ \dots \ \mathbf{A}^{n-1}\mathbf{B}]. \quad (14.4)$$

系统可控当且仅当 $\text{rank } \mathcal{C}(\mathbf{A}, \mathbf{B}) = n$ 。

证明. 取 $N = n$ ，把输入按逆时间顺序堆叠，受控增量为

$$\mathcal{C}(\mathbf{A}, \mathbf{B}) \begin{bmatrix} \mathbf{u}_{n-1} \\ \mathbf{u}_{n-2} \\ \vdots \\ \mathbf{u}_0 \end{bmatrix}.$$

若矩阵满行秩，它的列张成 $\mathbb{R}^n$ ，所以对任意 $\mathbf{x}_f - \mathbf{A}^n \mathbf{x}_0$ 都能找到输入。反之，若列空间是真子空间，Cayley-Hamilton 定理使 $\mathbf{A}^n$ 成为 $\mathbf{I}, \mathbf{A}, \dots, \mathbf{A}^{n-1}$ 的线性组合。继续乘 $\mathbf{A}$ ，每个 $\mathbf{A}^k \mathbf{B}$ ($k \geq n$) 仍在同一列空间中。延长时域无法增加可达方向，从零出发便不能到达该空间之外的状态。 ■

标量积分系统 $x_{t+1} = x_t + u_t$ 只需 $u_0 = x_f - x_0$ 便能一步到达目标。温度模型则取 $u_0 = x_f - 0.8x_0$ ；这里允许任意实数输入，不能据此断言只能加热且功率有限的执行器也能一步实现任意目标。标量例中，输入直接改变唯一的状态。若状态有多个坐标，输入也可能先改变一个坐标，再通过系统运动影响另一个。下面的二维系统展示这种间接作用：

$$\mathbf{A} = \begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix}, \quad \mathbf{B} = \begin{bmatrix} 0 \\ 1 \end{bmatrix}, \quad [\mathbf{B} \ \mathbf{AB}] = \begin{bmatrix} 0 & 1 \\ 1 & 1 \end{bmatrix}.$$

当前输入先改变第二个坐标，再经传播影响第一个坐标；矩阵满秩，两坐标均可达。若改为 $\mathbf{A} = \mathbf{I}, \mathbf{B} = (1, 0)^\top$ ，输入始终只能改变第一个坐标。

图 14.1 保留上述二维例，暂加 $|u_0|, |u_1| \leq 1$ 以画出有限区域。从零出发， $\mathbf{x}_2 = (u_0, u_0 + u_1)^\top$ 形成平行四边形；解除幅值限制后，两个独立方向才张成整个平面。




图 14.1 教学系统 $\mathbf{A} = \begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix}$ 、 $\mathbf{B} = (0, 1)^\top$ 从零出发。蓝色线段为 $|u_0| \leq 1$ 的一步可达集合，红色区域为 $|u_0|, |u_1| \leq 1$ 的两步可达集合；箭头为 $\mathbf{B}$ 与 $\mathbf{AB}$ 。幅值限制用于显示可达区域，不属于无约束可控性秩判据的假设。

连续时间系统 $\dot{\mathbf{x}}_t = \mathbf{A}\mathbf{x}_t + \mathbf{B}\mathbf{u}_t$ 在固定 $T > 0$ 上的终态为

$$\mathbf{x}_T = e^{\mathbf{A}T} \mathbf{x}_0 + \int_0^T e^{\mathbf{A}(T-s)} \mathbf{B} \mathbf{u}_s \, ds.$$

这里允许 $\mathbf{u} \in L^2([0, T]; \mathbb{R}^m)$ ，不加幅值限制。输入通过积分累积，对应的可控 Gram 矩阵 (controllability Gramian) 为

$$\mathbf{W}_c(T) = \int_0^T e^{\mathbf{A}s} \mathbf{B} \mathbf{B}^\top e^{\mathbf{A}^\top s} \, ds. \quad (14.5)$$

系统在 $[0, T]$ 可控当且仅当 $W_c(T) > \mathbf{0}$ 。证明先说明奇异矩阵为什么留下不可达方向，再为正定矩阵构造到达任意目标的输入。为此计算

$$\mathbf{q}^\top W_c(T) \mathbf{q} = \int_0^T \|\mathbf{B}^\top e^{\mathbf{A}^\top s} \mathbf{q}\|_2^2 ds.$$

若矩阵奇异，某个非零 $\mathbf{q}$ 使连续的非负被积函数恒为零，于是该方向与全部受控终态增量正交。若矩阵正定，对 $\mathbf{d} = \mathbf{x}_f - e^{\mathbf{A}T} \mathbf{x}_0$ 取

$$\mathbf{u}_s = \mathbf{B}^\top e^{\mathbf{A}^\top(T-s)} W_c(T)^{-1} \mathbf{d},$$

代回便得到终态增量 $\mathbf{d}$ 。被积函数恒为零使 $\mathbf{B}^\top e^{\mathbf{A}^\top s} \mathbf{q}$ 恒为零；对这个向量函数在 $s=0$ 逐阶求导，得到 $\mathbf{q}^\top \mathbf{A}^k \mathbf{B} = 0$ 。反向由矩阵指数级数成立；再结合 Cayley-Hamilton 定理，可知连续系统同样由式 (14.4) 判定。离散情形的对应 Gram 矩阵为 $\sum_{j=0}^{N-1} \mathbf{A}^j \mathbf{B} \mathbf{B}^\top (\mathbf{A}^\top)^j$ 。这些结论依赖线性结构，不能用一点的线性化代替非线性系统的全局可控性。

若只想定位哪个模式不受输入影响，可以直接检查左特征向量。

定理 14.4 Popov-Belevitch-Hautus(PBH)可控性判据 矩阵对 $(\mathbf{A}, \mathbf{B})$ 可控，当且仅当对每个复特征值 $\lambda \in \sigma(\mathbf{A})$,

$$\text{rank}[\lambda \mathbf{I} - \mathbf{A} \mathbf{B}] = n. \quad (14.6)$$

等价地，不存在非零左特征向量 $\mathbf{q}^*$ 同时满足 $\mathbf{q}^* \mathbf{A} = \lambda \mathbf{q}^*$ 和 $\mathbf{q}^* \mathbf{B} = \mathbf{0}$ 。

证明. 若存在这样的向量，则 $\mathbf{q}^* \mathbf{A}^k \mathbf{B} = \lambda^k \mathbf{q}^* \mathbf{B} = \mathbf{0}$ 对所有 $k \geq 0$ 成立，所以可控性矩阵不可能满行秩。反之，其列空间 $\mathbf{R}_{\text{reach}}$ 若不满维，便是一个真 $\mathbf{A}$ 不变子空间。正交补 $\mathbf{R}_{\text{reach}}^\perp$ 在 $\mathbf{A}^*$ 下不变。在复数域上，这个非零有限维不变子空间包含 $\mathbf{A}^*$ 的一个特征向量 $\mathbf{q}$ 。它正交于 $\mathbf{B}$ 的每一列，因此对应的左特征向量满足 $\mathbf{q}^* \mathbf{B} = \mathbf{0}$ ，PBH 矩阵在相应特征值处不满秩。 ■

终点可控仍不保证任意指定的中间状态都能实现。给定整条参考 $\mathbf{r}_t$ ，离散系统要求每一步 $\mathbf{r}_{t+1} - \mathbf{A} \mathbf{r}_t \in \text{col}(\mathbf{B})$ ，并且解出的输入位于允许集合；连续系统则要求参考绝对连续且 $\dot{\mathbf{r}}_t - \mathbf{A} \mathbf{r}_t = \mathbf{B} \mathbf{u}_t^*$ 几乎处处成立。终点可达回答“能否到那里”，而实现整条参考轨迹还要回答“能否按这条路走”。

14.1.3 观测条件下的状态可区分性

已知输入对输出的贡献可以计算并扣除。因此，比较同一输入下的两个初态时，只需考虑自由响应。为简化记号，下式中的 $\mathbf{y}_t$ 表示已经扣除已知输入贡献的输出，于是前 n 次输出满足

$$\begin{bmatrix} \mathbf{y}_0 \\ \mathbf{y}_1 \\ \vdots \\ \mathbf{y}_{n-1} \end{bmatrix} = \underbrace{\begin{bmatrix} \mathbf{C} \\ \mathbf{CA} \\ \vdots \\ \mathbf{CA}^{n-1} \end{bmatrix}}_{\mathcal{O}(\mathbf{C}, \mathbf{A})} \mathbf{x}_0. \quad (14.7)$$

定义 14.5 可观测性 若同一已知输入下的输出序列能够区分任意两个不同初态，称 $(\mathbf{C}, \mathbf{A})$ 可观测 (observable)。对上述线性时不变系统，这等价于 $\mathcal{O}(\mathbf{C}, \mathbf{A})$ 满列秩。

满列秩使式 (14.7) 对初态至多有一个解。反之，若秩不足，存在 $\mathbf{v} \neq \mathbf{0}$ 满足 $\mathcal{O}\mathbf{v} = \mathbf{0}$ ，初态 $\mathbf{x}_0$ 与 $\mathbf{x}_0 + \mathbf{v}$ 的前 n 次输出便相同。Cayley-Hamilton 定理使以后所有 $\mathbf{CA}^k \mathbf{v}$ 也是前 n 项的线性组合，延长观测仍无法区分两者。这同时证明了定义中的等价关系。对可控性 PBH 判据取转置，得到可观测性条件

$$\text{rank} \begin{bmatrix} \lambda \mathbf{I} - \mathbf{A} \\ \mathbf{C} \end{bmatrix} = n \quad \text{对每个 } \lambda \in \sigma(\mathbf{A}). \quad (14.8)$$

连续时间在任意固定正时长、无噪声的完整输出上也有相同秩条件；等价的观测 Gram 矩阵是 $\int_0^T e^{\mathbf{A}^\top s} \mathbf{C}^\top \mathbf{C} e^{\mathbf{A}s} ds$ 。

温度模型的 $\mathbf{C} = 1$ 使无噪声当前读数就能区分状态。有噪声时，同一个读数可能来自多个状态，结构可观测性并不提供单次误差上界。第 13.5 节建立的预测、滤波和平滑还需初态分布与噪声规律才能计算估计精度。本章接下来使用较弱的可检测条件，判断哪些看不见的误差仍能自行衰减，而不要求把所有状态都精确恢复。

14.2 策略的轨迹收敛与稳定

可控性判断输入的结构能力，稳定性判断所选反馈实际产生的长期行为。第 13.3 节已区分平衡点稳定、渐近稳定与指数稳定。在线性定常系统中，以下“稳定矩阵”统一指离散时间特征值模小于 1，或连续时间特征值实部小于 0；它们都给出齐次系统的指数衰减。有持续噪声时，所讨论的是齐次初始误差衰减和受迫二阶矩有界，不能称为每条路径趋零。

14.2.1 不可控与不可观测模式的稳定条件

反馈 $\mathbf{u} = -\mathbf{K}\mathbf{x}$ 把状态矩阵改为 $\mathbf{A} - \mathbf{BK}$ 。这个矩阵的特征值称为闭环极点 (closed-loop poles)，它们决定线性齐次响应的衰减或增长。为了使状态偏差最终消退，只需要通过反馈改变原先不衰减的模式；已经自行衰减的方向可以保留。这个较弱的要求称为稳定化。

定义 14.6 可稳定性 若存在 $\mathbf{K}$ 使 $\mathbf{A} - \mathbf{BK}$ 稳定，称矩阵对 $(\mathbf{A}, \mathbf{B})$ 可稳定 (stabilizable)。稳定区域按系统采用的离散或连续时间确定。

从可控性走到固定反馈的存在性，还要用到极点配置定理：对实可控对 $(\mathbf{A}_c, \mathbf{B}_c)$ ，任给次数等于其状态维数的实首一多项式，都存在实增益 $\mathbf{K}_c$ ，使该多项式成为 $\mathbf{A}_c - \mathbf{B}_c\mathbf{K}_c$ 的特征多项式。因此可以选择全部根位于单位圆内，或在连续时间选择全部根位于左半平面。这里引用这一标准存在定理；它不是仅由“有限时间可以到达任意终点”一句话直接推出的结论¹。

¹ H. K. Khalil, *Nonlinear Systems*, Prentice Hall, 2002, 3rd ed.

在前面的二维传播例中，取 $\mathbf{A} = \begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix}$ 、 $\mathbf{B} = (0, 1)^\top$ 和 $\mathbf{K} = (k_1, k_2)$ ，可直接算得

$$\det(\lambda\mathbf{I} - \mathbf{A} + \mathbf{BK}) = \lambda^2 + (k_2 - 2)\lambda + 1 - k_2 + k_1.$$

希望闭环根为 0.2, 0.5 时，将系数与 $(\lambda - 0.2)(\lambda - 0.5) = \lambda^2 - 0.7\lambda + 0.1$ 比较，得到 $k_2 = 1.3, k_1 = 0.4$ 。这个例子展示怎样用固定增益安排谱，而不再逐时刻另选输入序列。

令 $\mathbf{R}_{\text{reach}}$ 为可控性矩阵的列空间，选取以其一组基为前若干列的可逆矩阵 $\mathbf{T}$ 。由于 $\mathbf{A}\mathbf{R}_{\text{reach}} \subseteq \mathbf{R}_{\text{reach}}$ 且 $\text{col}(\mathbf{B}) \subseteq \mathbf{R}_{\text{reach}}$ ，坐标 $\mathbf{z}_t = \mathbf{T}^{-1}\mathbf{x}_t$ 给出

$$\mathbf{T}^{-1}\mathbf{A}\mathbf{T} = \begin{bmatrix} \mathbf{A}_c & \mathbf{A}_{1,2} \\ \mathbf{0} & \mathbf{A}_{uc} \end{bmatrix}, \quad \mathbf{T}^{-1}\mathbf{B} = \begin{bmatrix} \mathbf{B}_c \\ \mathbf{0} \end{bmatrix},$$

其中 $(\mathbf{A}_c, \mathbf{B}_c)$ 可控。这是可控分解：上块接收输入，下块只能自行演化。把 $\mathbf{KT}$ 写成 $[\mathbf{K}_c \ \mathbf{K}_{uc}]$ ，闭环矩阵成为

$$\begin{bmatrix} \mathbf{A}_c - \mathbf{B}_c\mathbf{K}_c & \mathbf{A}_{1,2} - \mathbf{B}_c\mathbf{K}_{uc} \\ \mathbf{0} & \mathbf{A}_{uc} \end{bmatrix}.$$

可控块可以用极点配置选择稳定特征值，不可控块的特征值却不受反馈影响。因此可稳定当且仅当不可控块本身稳定，PBH 形式为

$$\text{rank}[\lambda\mathbf{I} - \mathbf{A} \ \mathbf{B}] = n \quad \text{对每个 } |\lambda| \geq 1. \quad (14.9)$$

只需检查 $\mathbf{A}$ 的特征值，其余 λ 自动满足秩条件；连续时间把 $|\lambda| \geq 1$ 换成 $\text{Re } \lambda \geq 0$ 。

示例 14.7 不可控但可稳定的系统 取

$$\mathbf{A} = \begin{bmatrix} 1.2 & 0 \\ 0 & 0.5 \end{bmatrix}, \quad \mathbf{B} = \begin{bmatrix} 1 \\ 0 \end{bmatrix}.$$

可控性矩阵 $[\mathbf{B} \ \mathbf{A}\mathbf{B}] = \begin{bmatrix} 1 & 1.2 \\ 0 & 0 \end{bmatrix}$ 仅有秩 1。第二个模式不可控，但其特征值 0.5 已经稳定。取 $\mathbf{K} = (1, 0)$ ，闭环特征值为 0.2, 0.5，所以系统可稳定。若交换 $\mathbf{B}$ 的两个分量，输入只能作用到 0.5 模式，1.2 模式不可控，系统便不可稳定。

传感器一侧有对应的问题：无法识别的初始误差，能否不经校正就逐渐消失？

定义 14.8 可检测性 若存在 $\mathbf{L}$ 使 $\mathbf{A} - \mathbf{L}\mathbf{C}$ 稳定，称 $(\mathbf{C}, \mathbf{A})$ 可检测 (detectable)。

它不要求每个初态都可恢复，只要求不可观测的模式自行稳定。其离散 PBH 条件为

$$\text{rank} \begin{bmatrix} \lambda \mathbf{I} - \mathbf{A} \\ \mathbf{C} \end{bmatrix} = n \quad \text{对每个 } |\lambda| \geq 1. \quad (14.10)$$

这一等价关系来自转置对偶： $(\mathbf{A}^\top, \mathbf{C}^\top)$ 的可控性矩阵的转置，正是 $(\mathbf{C}, \mathbf{A})$ 的观测矩阵。对前者作可控分解，其不可控块对应原系统的不可观测模式，又有 $\mathbf{A}^\top - \mathbf{C}^\top \mathbf{L}^\top = (\mathbf{A} - \mathbf{L}\mathbf{C})^\top$ 。因此，不可观测块稳定时可配置其余误差模式；存在不可观测的非衰减模式时，任何 $\mathbf{L}$ 都无法移动它。连续时间同样用闭右半平面替换单位圆外。

继续取示例 14.7 的 $\mathbf{A}$ 。 $\mathbf{C} = (1, 0)$ 看得见 1.2 模式，看不见会自行衰减的 0.5 模式，所以不可观测却可检测。改用 $\mathbf{C} = (0, 1)$ 便看不到危险模式，任何估计器的确定性初始误差都不能依靠输出把该方向统一消除。表 14.1 汇总四种条件；输入或观测能否影响全部方向，与是否足以保证长期稳定，是不同的要求。

性质	所比较的对象	哪些方向必须处理	二维例的判断
可控	输入与终态	全部状态方向	否，输入无法改变第二坐标
可稳定	反馈与闭环谱	不稳定及临界模式	是，1.2 模式受控
可观测	初态与输出序列	全部状态方向	否，输出不含第二坐标
可检测	观测器与误差谱	不稳定及临界模式	是，1.2 模式可见

表 14.1 固定 $\mathbf{A} = \text{diag}(1.2, 0.5)$ 、 $\mathbf{B} = (1, 0)^\top$ 、 $\mathbf{C} = (1, 0)$ 比较四种结构条件。第二模式虽不可控、不可观测，却自行衰减；若把其特征值改为 1.1，可稳定与可检测也会失败。连续时间按实部判断危险模式。

14.2.2 状态反馈下的闭环稳定

结构条件允许稳定化以后，仍需选定反馈并检查实际闭环。线性状态反馈给出

$$\mathbf{u}_t = -\mathbf{K}\mathbf{x}_t, \quad \mathbf{x}_{t+1} = (\mathbf{A} - \mathbf{BK})\mathbf{x}_t. \quad (14.11)$$

负号只是增益约定。按定理 13.14，闭环渐近稳定当且仅当 $\rho(\mathbf{A} - \mathbf{BK}) < 1$ 。也可以按定理 13.17 找 $\mathbf{P} > \mathbf{0}$ ，使 $\mathbf{P} - \mathbf{F}^\top \mathbf{P} \mathbf{F} > \mathbf{0}$ ，其中 $\mathbf{F} = \mathbf{A} - \mathbf{BK}$ 。连续时间则检查 $\mathbf{F}$ 的特征值实部或 $\mathbf{F}^\top \mathbf{P} + \mathbf{P} \mathbf{F} < \mathbf{0}$ 。

不同稳定增益并不产生同样的响应。在无约束、无噪声的温度模型中先以零为目标，取 $\mathbf{u}_t = -k\mathbf{x}_t$ ，有 $\mathbf{x}_t = (0.8 - k)^t \mathbf{x}_0$ 。增益 $k = 0.3$ 使系数为 0.5， $k = 0.7$ 使系数为 0.1；对相同初态，后者每步收缩更多，却把初始输入幅值从 $0.3|\mathbf{x}_0|$ 提高到 $0.7|\mathbf{x}_0|$ 。取 $k = 1.4$ 则得到 -0.6 ，状态交替过零，收敛反而比 0.5 慢。稳定范围是 $-0.2 < k < 1.8$ ，不是增益越大越快；有饱和时这些线性计算也不再直接适用。

多维系统还要区分渐近速度与瞬态放大。比较

$$\mathbf{F}_1 = 0.5\mathbf{I}, \quad \mathbf{F}_2 = \begin{bmatrix} 0.5 & 4 \\ 0 & 0.5 \end{bmatrix}.$$

二者特征值均为 0.5，但从 $(0, 1)^\top$ 出发，第一步的状态范数分别为 0.5 和 $\sqrt{16.25} > 4$ 。事实上

$$\mathbf{F}_2^t = \begin{bmatrix} 0.5^t & 4t \cdot 0.5^{t-1} \\ 0 & 0.5^t \end{bmatrix} \quad (t \geq 1).$$

非对角耦合先放大误差，随后才被指数衰减压低。两者都可以在 $\mathbf{A} = \mathbf{B} = \mathbf{I}$ 的系统中由 $\mathbf{K}_i = \mathbf{I} - \mathbf{F}_i$ 实现，第二种增益也引入较强的交叉输入。因此评价反馈时应共同看 $\|\mathbf{F}^t\|_2$ 、输入 $\|\mathbf{K}\mathbf{x}_t\|_2$ 与长期衰减，而不是仅比较最大特征值。二次成本在下一小节把状态偏差与输入幅值纳入同一准则，但“稳定”本身并没有选定这一偏好。

非线性系统无法靠一个常矩阵描述全部区域。此时可以先找一个衡量偏离程度的函数，再选动作让它下降，这就是控制 Lyapunov 方法。

定义 14.9 控制 Lyapunov 函数条件 考虑 $\dot{\mathbf{x}}_t = \mathbf{f}(\mathbf{x}_t) + \mathbf{G}(\mathbf{x}_t)\mathbf{u}_t$ ，目标为原点，输入属于 U 。若某邻域内的 C^1 函数 V 满足 $V(\mathbf{0}) = 0$ 、 $V(\mathbf{x}) > 0$ ($\mathbf{x} \neq \mathbf{0}$)，且有正定连续函数 W 使

$$\inf_{\mathbf{u} \in U} \nabla V(\mathbf{x})^\top (\mathbf{f}(\mathbf{x}) + \mathbf{G}(\mathbf{x})\mathbf{u}) \leq -W(\mathbf{x}),$$

称 V 提供一个控制 Lyapunov 函数 (control Lyapunov function, CLF) 条件: 每个非零状态至少应能选择一个使偏离量严格下降的动作。调用反馈稳定性结论时, 还要求下降动作确实可取到。

点态存在动作不等于已经构造出适定反馈。若能选出局部 Lipschitz 反馈 κ , 使原点为平衡、且沿闭环 $\dot{V} \leq -W$, 即可回用定理 13.18 得到局部渐近稳定。若进一步有 $c_1 \|\mathbf{x}\|_2^2 \leq V \leq c_2 \|\mathbf{x}\|_2^2$ 和 $W \geq c_3 \|\mathbf{x}\|_2^2$, 便有 $V_t \leq e^{-c_3 t/c_2} V_0$; 全局结论还需全域条件与解的延拓。例如 $\dot{x}_t = x_t^3 + u_t$ 取 $V(x) = x^2/2$ 、 $u_t = -x_t^3 - kx_t$ ($k > 0$), 得到 $\dot{V} = -kx_t^2$ 和 $x_t = e^{-kt}x_0$ 。这个反馈在无界输入下成立; 若 $|u_t| \leq u_{\max}$, 大状态处抵消 x_t^3 所需的动作可能不可行, 只能在经过核验的区域中声明稳定²。

14.2.3 二次反馈下的稳定化解

要在减小状态偏差与限制输入幅值之间作出具体选择, 可以分别给两者加上二次代价。这一特例能够通过逐步配方直接算出反馈, 无须先掌握一般价值优化理论。

定义 14.10 有限时域线性二次调节 考虑状态完全可见的系统

$$\mathbf{x}_{t+1} = \mathbf{A}\mathbf{x}_t + \mathbf{B}\mathbf{u}_t + \mathbf{w}_{t+1}, \quad t = 0, \dots, T-1, \quad (14.12)$$

以及风险中性的期望成本

$$J = \mathbb{E} \left[\mathbf{x}_T^\top \mathbf{Q}_T \mathbf{x}_T + \sum_{t=0}^{T-1} (\mathbf{x}_t^\top \mathbf{Q} \mathbf{x}_t + \mathbf{u}_t^\top \mathbf{R} \mathbf{u}_t) \right]. \quad (14.13)$$

其中 $\mathbf{Q}, \mathbf{Q}_T \geq \mathbf{0}$ 为 $n \times n$ 对称矩阵, $\mathbf{R} > \mathbf{0}$ 为 $m \times m$ 对称矩阵。输入无幅值限制。在非预见的状态反馈策略中最小化 J , 称为线性二次调节 (linear-quadratic regulation, LQR)。

本小节的 $\mathbf{w}_t$ 服从固定但不必高斯的分布, 均值为零, 协方差为 Σ_w , 各时刻独立并独立于初态; 初态二阶矩有限。动作对截至 t 的状态历史 $\mathcal{F}_t = \sigma(\mathbf{x}_0, \dots, \mathbf{x}_t)$ 可测, 因而 $\mathbf{w}_{t+1}$ 独立于当前状态和动作。状态代价半正定允许某些方向不直接计价, 控制代价正定保证每一步动作最小化严格凸。

用 Π_t 表示从 t 到 $T-1$ 、适应上述状态信息的允许策略，以 $\mathbb{E}_{t,\mathbf{x}}$ 表示从时刻 t 的状态 $\mathbf{x}$ 开始运行所得的期望。最优剩余成本定义为

$$V_t(\mathbf{x}) = \inf_{\pi \in \Pi_t} \mathbb{E}_{t,\mathbf{x}} \left[\mathbf{x}_T^\top \mathbf{Q}_T \mathbf{x}_T + \sum_{\tau=t}^{T-1} (\mathbf{x}_\tau^\top \mathbf{Q} \mathbf{x}_\tau + \mathbf{u}_\tau^\top \mathbf{R} \mathbf{u}_\tau) \right].$$

这里的下确界取遍反馈策略而不是预先固定的动作序列；终端为 $V_T(\mathbf{x}) = \mathbf{x}^\top \mathbf{Q}_T \mathbf{x}$ 。将当前阶段与未来分开，条件期望的迭代性质给出

$$V_t(\mathbf{x}) = \min_{\mathbf{u}} \{ \mathbf{x}^\top \mathbf{Q} \mathbf{x} + \mathbf{u}^\top \mathbf{R} \mathbf{u} + \mathbb{E}[V_{t+1}(\mathbf{A}\mathbf{x} + \mathbf{B}\mathbf{u} + \mathbf{w}_{t+1})] \}. \quad (14.14)$$

对任意策略，后续成本至少为下一状态的 V_{t+1} ；若下一步的下界可由反馈取得，先选当前极小动作，再接上该反馈，就取得等号。下面的反向归纳同时构造这些可取到的动作，因此这里不依赖尚未证明的一般最优策略存在性。这一递推的通用形式将在第 15 章展开³。

³ B. D. O. Anderson, J. B. Moore, *Optimal Control: Linear Quadratic Methods*, Dover Publications, 2007

定理 14.11 有限时域 LQR 与 Riccati 递推 在上述条件下， $V_t(\mathbf{x}) = \mathbf{x}^\top \mathbf{P}_t \mathbf{x} + c_t$ ，其中 $\mathbf{P}_T = \mathbf{Q}_T$ 、 $c_T = 0$ 。令

$$\begin{aligned} \mathbf{S}_t &= \mathbf{R} + \mathbf{B}^\top \mathbf{P}_{t+1} \mathbf{B}, \\ \mathbf{K}_t &= \mathbf{S}_t^{-1} \mathbf{B}^\top \mathbf{P}_{t+1} \mathbf{A}, \end{aligned} \quad (14.15)$$

则最优动作是 $\mathbf{u}_t^* = -\mathbf{K}_t \mathbf{x}_t$ ，矩阵满足

$$\begin{aligned} \mathbf{P}_t &= \mathbf{Q} + \mathbf{A}^\top \mathbf{P}_{t+1} \mathbf{A} \\ &\quad - \mathbf{A}^\top \mathbf{P}_{t+1} \mathbf{B} \mathbf{S}_t^{-1} \mathbf{B}^\top \mathbf{P}_{t+1} \mathbf{A}, \end{aligned} \quad (14.16)$$

噪声只进入常数项

$$c_t = c_{t+1} + \text{tr}(\mathbf{P}_{t+1} \boldsymbol{\Sigma}_w). \quad (14.17)$$

证明. 在终端结论成立。假设 $t+1$ 时刻的表达和最优反馈已构造，记 $\mathbf{z} = \mathbf{A}\mathbf{x} + \mathbf{B}\mathbf{u}$ 。噪声的零均值、协方差与独立性给出

$$\mathbb{E}[V_{t+1}(\mathbf{z} + \mathbf{w}_{t+1})] = \mathbf{z}^\top \mathbf{P}_{t+1} \mathbf{z} + \text{tr}(\mathbf{P}_{t+1} \boldsymbol{\Sigma}_w) + c_{t+1}.$$

交叉项条件期望为零。将 $\mathbf{z}$ 展开，当前目标为

$$\begin{aligned} &\mathbf{x}^\top (\mathbf{Q} + \mathbf{A}^\top \mathbf{P}_{t+1} \mathbf{A}) \mathbf{x} + 2\mathbf{u}^\top \mathbf{B}^\top \mathbf{P}_{t+1} \mathbf{A} \mathbf{x} + \mathbf{u}^\top \mathbf{S}_t \mathbf{u} \\ &\quad + \text{tr}(\mathbf{P}_{t+1} \boldsymbol{\Sigma}_w) + c_{t+1}. \end{aligned}$$

由 $P_{t+1} \geq 0$ 、 $R > 0$ 得 $S_t > 0$ 。动作相关项可以完整配方：

$$\begin{aligned} & \mathbf{u}^\top S_t \mathbf{u} + 2\mathbf{u}^\top \mathbf{B}^\top P_{t+1} \mathbf{A} \mathbf{x} \\ &= (\mathbf{u} + \mathbf{K}_t \mathbf{x})^\top S_t (\mathbf{u} + \mathbf{K}_t \mathbf{x}) - \mathbf{x}^\top \mathbf{K}_t^\top S_t \mathbf{K}_t \mathbf{x}. \end{aligned}$$

平方项非负且仅在 $\mathbf{u} = -\mathbf{K}_t \mathbf{x}$ 处为零。合并剩余二次项与常数项，分别得到式 (14.16) 和式 (14.17)。所得二次型也是

$$\mathbf{x}^\top P_t \mathbf{x} = \min_{\mathbf{u}} \{ \mathbf{x}^\top \mathbf{Q} \mathbf{x} + \mathbf{u}^\top \mathbf{R} \mathbf{u} + (\mathbf{A} \mathbf{x} + \mathbf{B} \mathbf{u})^\top P_{t+1} (\mathbf{A} \mathbf{x} + \mathbf{B} \mathbf{u}) \},$$

故 $P_t \geq 0$ ，归纳可以继续。线性极小动作可测，并在有限时域保持二阶矩有限；将这些动作依次拼接，取得每一步下界，证明最优值确实可达。■

线性动态把二次型变为状态与动作的联合二次型，动作配方后又留下状态二次型。这解释了 Riccati 构造为何在本模型中闭合，也说明不能把非线性动态随意换成 Jacobian 就声称得到了原问题的精确解。噪声只影响常数项同样有边界：非零均值通常产生线性项和仿射偏置；噪声分布随动作或状态变化时，增益也可能变化；若目标更加重视成本很大的少数结果，即后文的尾部风险，原增益同样未必最优。若权重和噪声协方差是预先给定的逐时量，只需在第 t 步分别用 $\mathbf{Q}_t, \mathbf{R}_t, \Sigma_{w,t+1}$ 替换对应矩阵，保持 $\mathbf{Q}_t \geq 0, \mathbf{R}_t > 0$ 和独立零均值条件，同一反向归纳仍成立。

为了看清有限时域的成本最优为何未必保证长期稳定，下面把温度模型的衰减系数 0.8 改为增长系数 1.2，考察无输入时会放大状态的标量系统。取 $x_{t+1} = 1.2x_t + u_t$ 、 $Q = R = 1$ 且无噪声。记下一步系数为 $p = P_{t+1}$ ，当前目标的配方为

$$\begin{aligned} x^2 + u^2 + p(1.2x + u)^2 &= (1 + p) \left(u + \frac{1.2p}{1 + p} x \right)^2 \\ &\quad + \left(1 + 1.44p - \frac{1.44p^2}{1 + p} \right) x^2. \end{aligned}$$

因此

$$S_t = 1 + P_{t+1}, \quad K_t = \frac{1.2P_{t+1}}{1 + P_{t+1}}, \quad P_t = 1 + \frac{1.44P_{t+1}}{1 + P_{t+1}}.$$

若 $P_T = 0$ ，则 $P_{T-1} = 1, K_{T-1} = 0$ ；最后一个动作之后没有状态代价，故此时不用力。再向前一步有 $P_{T-2} = 1.72, K_{T-2} = 0.6$ 。有限时域的最优反馈未必在每一步都使闭环矩阵稳定， $K_{T-1} = 0$ 就是反例。所以有限时域内能够通过配方求出最优动作，并不能证明无限时域内存在稳定的最优反馈。

为处理长期稳定化, 现切换到确定性、时不变、无折扣系统, 即 $\mathbf{w}_{t+1} = \mathbf{0}$, 目标为

$$J_{\infty} = \sum_{t=0}^{\infty} (\mathbf{x}_t^{\top} \mathbf{Q} \mathbf{x}_t + \mathbf{u}_t^{\top} \mathbf{R} \mathbf{u}_t).$$

若反馈与二次系数不再随时间变化, 递推给出 离散代数 Riccati 方程 (discrete algebraic Riccati equation, DARE):

$$\begin{aligned} \mathbf{P} &= \mathbf{Q} + \mathbf{A}^{\top} \mathbf{P} \mathbf{A} \\ &\quad - \mathbf{A}^{\top} \mathbf{P} \mathbf{B} (\mathbf{R} + \mathbf{B}^{\top} \mathbf{P} \mathbf{B})^{-1} \mathbf{B}^{\top} \mathbf{P} \mathbf{A}. \end{aligned} \quad (14.18)$$

所需的稳定化解 (stabilizing solution) 不仅满足 $\mathbf{P} \geq \mathbf{0}$, 还要求其增益 $\mathbf{K} = (\mathbf{R} + \mathbf{B}^{\top} \mathbf{P} \mathbf{B})^{-1} \mathbf{B}^{\top} \mathbf{P} \mathbf{A}$ 使闭环稳定。

定理 14.12 无限时域 LQR 的稳定化解 设 $\mathbf{Q} \geq \mathbf{0}$ 、 $\mathbf{R} > \mathbf{0}$, $(\mathbf{A}, \mathbf{B})$ 可稳定且 $(\mathbf{Q}^{1/2}, \mathbf{A})$ 可检测。则式 (14.18) 存在唯一半正定稳定化解 $\mathbf{P}$ 。相应反馈使闭环渐近稳定, 并在所有允许控制序列中给出无折扣二次总成本的最优值 $V(\mathbf{x}) = \mathbf{x}^{\top} \mathbf{P} \mathbf{x}$ 。

证明. 取长度 N 、终端代价为零的有限问题, 记其初始价值矩阵为 $\mathbf{P}^{(N)}$ 。增加一个非负阶段成本不能降低最优成本, 故 $\mathbf{0} \leq \mathbf{P}^{(N)} \leq \mathbf{P}^{(N+1)}$ 。可稳定性提供 $\bar{\mathbf{K}}$ 使 $\bar{\mathbf{F}} = \mathbf{A} - \mathbf{B} \bar{\mathbf{K}}$ 稳定。始终用此反馈的成本矩阵为

$$\bar{\mathbf{P}} = \sum_{j=0}^{\infty} (\bar{\mathbf{F}}^{\top})^j (\mathbf{Q} + \bar{\mathbf{K}}^{\top} \mathbf{R} \bar{\mathbf{K}}) \bar{\mathbf{F}}^j,$$

级数由指数衰减收敛, 且 $\mathbf{P}^{(N)} \leq \bar{\mathbf{P}}$ 。每个二次型 $\mathbf{x}^{\top} \mathbf{P}^{(N)} \mathbf{x}$ 单调有界, 再用极化恒等式恢复矩阵各元素, 得到 $\mathbf{P}^{(N)} \rightarrow \mathbf{P} \geq \mathbf{0}$ 。Riccati 映射连续, 因为待逆矩阵始终不小于 $\mathbf{R} > \mathbf{0}$; 对 $\mathbf{P}^{(N+1)} = \mathcal{R}(\mathbf{P}^{(N)})$ 取极限得到 DARE。

令 $\mathbf{F} = \mathbf{A} - \mathbf{B} \mathbf{K}$, DARE 按增益改写为

$$\mathbf{P} - \mathbf{F}^{\top} \mathbf{P} \mathbf{F} = \mathbf{Q} + \mathbf{K}^{\top} \mathbf{R} \mathbf{K}. \quad (14.19)$$

若 $\mathbf{F} \mathbf{z} = \lambda \mathbf{z}$ 且 $\mathbf{z} \neq \mathbf{0}$, $|\lambda| \geq 1$, 在两侧乘 $\mathbf{z}^*, \mathbf{z}$ 得到

$$(1 - |\lambda|^2) \mathbf{z}^* \mathbf{P} \mathbf{z} = \|\mathbf{Q}^{1/2} \mathbf{z}\|_2^2 + \|\mathbf{R}^{1/2} \mathbf{K} \mathbf{z}\|_2^2.$$

左侧非正, 右侧非负, 所以均为零, 特别有 $\mathbf{Q}^{1/2} \mathbf{z} = \mathbf{0}, \mathbf{K} \mathbf{z} = \mathbf{0}$ 。于是 $\mathbf{A} \mathbf{z} = (\mathbf{F} + \mathbf{B} \mathbf{K}) \mathbf{z} = \lambda \mathbf{z}$, 违反 $(\mathbf{Q}^{1/2}, \mathbf{A})$ 的可检测性。因此 $\mathbf{F}$ 稳定。

存在且稳定还不足以完成最优性证明。记 $S = R + B^T P B$, 对任意控制沿前 N 步累加配方恒等式:

$$\begin{aligned} & \sum_{t=0}^{N-1} (\mathbf{x}_t^T Q \mathbf{x}_t + \mathbf{u}_t^T R \mathbf{u}_t) + \mathbf{x}_N^T P \mathbf{x}_N \\ &= \mathbf{x}_0^T P \mathbf{x}_0 + \sum_{t=0}^{N-1} (\mathbf{u}_t + K \mathbf{x}_t)^T S (\mathbf{u}_t + K \mathbf{x}_t). \end{aligned}$$

不能直接丢弃左侧终端项。若该控制的总成本有限, 非负级数的项趋零, 给出 $Q^{1/2} \mathbf{x}_t \rightarrow \mathbf{0}$ 及 $\mathbf{u}_t \rightarrow \mathbf{0}$, 后者使用 $R > \mathbf{0}$ 。可检测性提供 L 使 $H = A - LQ^{1/2}$ 稳定, 于是

$$\mathbf{x}_{t+1} = H \mathbf{x}_t + \underbrace{B \mathbf{u}_t + L Q^{1/2} \mathbf{x}_t}_{\mathbf{d}_t \rightarrow \mathbf{0}}.$$

展开为 $H^t \mathbf{x}_0 + \sum_{j=0}^{t-1} H^{t-1-j} \mathbf{d}_j$ 。有限个早期输入的贡献随 t 衰减; 晚期输入任意小, 且 $\sum_{j \geq 0} \|H^j\|_2 < \infty$, 故卷积尾部也趋零。因此 $\mathbf{x}_t \rightarrow \mathbf{0}$, 终端项趋零。

令 $N \rightarrow \infty$, 任何有限成本控制的成本都是 $\mathbf{x}_0^T P \mathbf{x}_0$ 加上一串非负平方项。采用 $\mathbf{u}_t = -K \mathbf{x}_t$ 时平方项全为零, 闭环稳定保证终端项趋零和总成本有限, 故达到下界; 无限成本控制自然不能优于它。若另有半正定稳定化解, 同一配方和终端项论证也使它表示全部初态上的同一个最优成本。两个对称矩阵的二次型处处相等, 矩阵便相等, 唯一性得证。 ■

在前述 $A = 1.2, B = 1, Q = R = 1$ 例中,

$$P = 1 + \frac{1.44P}{1+P}, \quad P^2 - 1.44P - 1 = 0,$$

半正定根与反馈为

$$P = \frac{1.44 + \sqrt{6.0736}}{2} \approx 1.952, \quad K = \frac{1.2P}{1+P} \approx 0.794, \quad 1.2 - K \approx 0.406.$$

另一个根为负, 不表示非负总成本。可检测条件中的“输出”是成本所见的 $Q^{1/2} \mathbf{x}$, 不是传感器的 $C \mathbf{x}$; 两种可检测条件不能替换。

若 $A = 1.2, B = 1, Q = 0, R = 1$, 系统可控却不满足成本可检测性。DARE 有 $P = 0$ 与 $P = 0.44$ 两个半正定根。前者给 $K = 0$ 和不稳定闭环 1.2, 后者给稳定闭环 5/6。原目标只惩罚控制, $\mathbf{u}_t = 0$ 以零成本全局最优, 稳定化反馈反而支付正成本。这个反例说明稳定化与成本最优之间的联系确实依赖假设。若恢复持续非零加性噪声, 稳定闭环通常有非零稳态协方差, 单步期望成本不趋零, 无折扣总期望成本通常发散; 除噪声传播恰好

不被成本计价等退化情形，应改用有限、折扣或长期平均成本，而不是沿用本定理的确定性总成本。

连续时间也可以直接用代数方程构造稳定反馈，无须先推导有限时域价值。对 $\dot{\mathbf{x}}_t = \mathbf{A}\mathbf{x}_t + \mathbf{B}\mathbf{u}_t$ ，连续代数 Riccati 方程（continuous algebraic Riccati equation, CARE）为

$$\mathbf{0} = \mathbf{Q} + \mathbf{A}^\top \mathbf{P} + \mathbf{P}\mathbf{A} - \mathbf{P}\mathbf{B}\mathbf{R}^{-1}\mathbf{B}^\top \mathbf{P}. \quad (14.20)$$

当 $\mathbf{Q} \geq \mathbf{0}, \mathbf{R} > \mathbf{0}$ ，且连续时间意义下 $(\mathbf{A}, \mathbf{B})$ 可稳定、 $(\mathbf{Q}^{1/2}, \mathbf{A})$ 可检测时，CARE 有唯一半正定稳定化解；这是连续线性二次控制的标准代数结论⁴。本处使用其存在性，具体闭环性质还可直接核验。令 $\mathbf{K} = \mathbf{R}^{-1}\mathbf{B}^\top \mathbf{P}$ 、 $\mathbf{F} = \mathbf{A} - \mathbf{B}\mathbf{K}$ ，则

$$\mathbf{F}^\top \mathbf{P} + \mathbf{P}\mathbf{F} = -(\mathbf{Q} + \mathbf{K}^\top \mathbf{R}\mathbf{K}).$$

若 $\mathbf{F}\mathbf{z} = \lambda\mathbf{z}$ 且 $\text{Re}\lambda \geq 0$ ，两侧二次型给出 $2\text{Re}\lambda \mathbf{z}^* \mathbf{P}\mathbf{z} = -\|\mathbf{Q}^{1/2}\mathbf{z}\|_2^2 - \|\mathbf{R}^{1/2}\mathbf{K}\mathbf{z}\|_2^2$ 。同样推出 $\mathbf{Q}^{1/2}\mathbf{z} = \mathbf{K}\mathbf{z} = \mathbf{0}$ ，与可检测性矛盾。所以闭环谱位于左半平面；即使 $\mathbf{P}$ 仅半正定，仍可由谱结论另解正定 Lyapunov 方程。连续有限时域微分 Riccati 及价值最优性在第 15 章主讲；本处的稳定核验不以它们为前提。

⁴ B. D. O. Anderson, J. B. Moore, *Optimal Control: Linear Quadratic Methods*, Dover Publications, 2007

14.2.4 输出反馈下的估计与闭环稳定

前面的反馈把真实状态直接写入动作公式。若控制器只有传感器读数，就需要说明怎样结合模型与读数形成状态估计，以及使用哪一时刻的估计计算动作。Luenberger 观测器（Luenberger observer）采用

$$\hat{\mathbf{x}}_{t+1} = \mathbf{A}\hat{\mathbf{x}}_t + \mathbf{B}\mathbf{u}_t + \mathbf{L}(\mathbf{y}_t - \mathbf{C}\hat{\mathbf{x}}_t). \quad (14.21)$$

无噪声时，误差 $\mathbf{e}_t^o = \mathbf{x}_t - \hat{\mathbf{x}}_t$ 满足 $\mathbf{e}_{t+1}^o = (\mathbf{A} - \mathbf{L}\mathbf{C})\mathbf{e}_t^o$ 。可检测性恰好允许选出误差衰减的 $\mathbf{L}$ 。若使用 $\mathbf{u}_t = -\mathbf{K}\hat{\mathbf{x}}_t$ ，联合系统为

$$\begin{bmatrix} \mathbf{x}_{t+1} \\ \mathbf{e}_{t+1}^o \end{bmatrix} = \begin{bmatrix} \mathbf{A} - \mathbf{B}\mathbf{K} & \mathbf{B}\mathbf{K} \\ \mathbf{0} & \mathbf{A} - \mathbf{L}\mathbf{C} \end{bmatrix} \begin{bmatrix} \mathbf{x}_t \\ \mathbf{e}_t^o \end{bmatrix}. \quad (14.22)$$

这个分离原理（separation principle）说的是闭环谱可以分开设计：特征行列式等于两个对角块特征行列式之积，故联合谱恰为二者的并集。当两块都稳定时，联合矩阵稳定；反过来，任一块的危险特征值也保留在联合谱中。因而确定性观测器与状态反馈可以分别作稳定设计；这一论证并未涉及成本最优。

有噪声时，还需区分预测协方差与观测更新后的协方差。在式 (14.12) 及 $\mathbf{y}_t = \mathbf{C}\mathbf{x}_t + \mathbf{v}_t$ 中，令 $\mathbf{w}_t, \mathbf{v}_t$ 分别为独立同分布零均值噪声，协方差为 $\Sigma_w \geq \mathbf{0}, \Sigma_v > \mathbf{0}$ ，两族与初态相互独立，初态二阶矩有限，估计器从先验均

值及协方差初始化。若要将 Kalman 估计解释为精确条件均值，再要求初态和噪声联合高斯；非高斯时以下递推仍描述相应线性滤波器的误差矩，不自动描述完整后验。

以 Π_t 记看到 y_t 之前的预测误差协方差。高斯情形下， $\hat{x}_{t|t-1}$ 是给定截至 $t-1$ 的观测及已执行控制后的条件均值。在初始时刻， Π_0 由尚未使用 y_0 的先验给出。更新增益 M_t 与合并预测增益 L_t 分别为

$$M_t = \Pi_t C^\top (C \Pi_t C^\top + \Sigma_v)^{-1}, \quad L_t = A M_t.$$

先更新再预测，可以写成

$$\hat{x}_{t+1|t} = A \hat{x}_{t|t-1} + B u_t + L_t (y_t - C \hat{x}_{t|t-1}).$$

所以预测误差的齐次矩阵为 $A - L_t C$ ，不能遗漏增益中的 A 。稳态预测协方差满足

$$\begin{aligned} \Pi &= A \Pi A^\top + \Sigma_w \\ &\quad - A \Pi C^\top (C \Pi C^\top + \Sigma_v)^{-1} C \Pi A^\top. \end{aligned} \quad (14.23)$$

控制 DARE 中作 $A \mapsto A^\top, B \mapsto C^\top, Q \mapsto \Sigma_w, R \mapsto \Sigma_v$ 便得到此式。公式的转置对偶联系的是两个矩阵计算问题，并不使状态成本与估计协方差具有相同含义。

定理 14.13 稳态预测滤波的充分条件 若 (C, A) 可检测、 $(A, \Sigma_w^{1/2})$ 可稳定，且 $\Sigma_v > 0$ ，则式 (14.23) 有唯一半正定稳定化解 Π 。从任意有限 $\Pi_0 \geq 0$ 出发的预测协方差递推收敛到 Π ，稳态 $L = A M$ 使 $A - LC$ 稳定。

证明. 对偶代换把本定理的两个结构条件分别变为无限 LQR 定理的可稳定、可检测条件，故解的存在、唯一与稳定性成立。为说明一般初始协方差的收敛，记滤波 Riccati 映射为 Φ 。固定任意合并增益 L ，定义

$$\Psi_L(X) = (A - LC)X(A - LC)^\top + \Sigma_w + L \Sigma_v L^\top.$$

配方表明 $\Phi(X) \leq \Psi_L(X)$ ，等号在对应 Kalman 增益处成立。又若 $X \geq Y$ ，每个固定增益下 $\Psi_L(X) \geq \Psi_L(Y)$ ；取 X 的极小增益使得 $\Phi(X) \geq \Phi(Y)$ 。取稳态增益 L ，有 $\Psi_L(\Pi) = \Pi$ ，并由单调性归纳得到

$$\Phi^t(0) \leq \Phi^t(\Pi_0) \leq \Psi_L^t(\Pi_0).$$

左端按对偶有限时域构造收敛到 Π ；右端与 Π 之差为 $(A - LC)^t(\Pi_0 - \Pi)[(A - LC)^\top]^t$ ，也趋零，夹逼得证。 ■

稳态滤波误差仍由新噪声持续驱动：

$$\mathbf{e}_{t+1}^p = (\mathbf{A} - \mathbf{LC})\mathbf{e}_t^p + \mathbf{w}_{t+1} - \mathbf{Lv}_t.$$

稳定性使初始误差的影响衰减，协方差趋于有限的 $\mathbf{\Pi}$ ，并不使噪声消失。温度例取 $\Sigma_w = 0.04, \Sigma_v = 0.09$ ，稳态方程为 $\mathbf{\Pi} = 0.64\mathbf{\Pi} + 0.04 - 0.64\mathbf{\Pi}^2/(\mathbf{\Pi} + 0.09)$ ，即 $\mathbf{\Pi}^2 - 0.0076\mathbf{\Pi} - 0.0036 = 0$ 。正根约为 0.06392， $M \approx 0.4153, L \approx 0.3322$ ，预测齐次误差系数约为 0.4678；稳态预测误差方差为正：即使初始估计误差已消退，新噪声仍会不断造成偏差，所以不能说每条估计误差路径都趋于零。

实际控制可使用当前观测更新后的 $\hat{\mathbf{x}}_{t|t}$ 。取 $\mathbf{u}_t = -\mathbf{K}\hat{\mathbf{x}}_{t|t}$ ，并用预测误差 $\mathbf{e}_t^p = \mathbf{x}_t - \hat{\mathbf{x}}_{t|t-1}$ ，齐次联合矩阵变为

$$\begin{bmatrix} \mathbf{A} - \mathbf{BK} & \mathbf{BK}(\mathbf{I} - \mathbf{MC}) \\ \mathbf{0} & \mathbf{A}(\mathbf{I} - \mathbf{MC}) \end{bmatrix}.$$

附加噪声为 $((\mathbf{w}_{t+1} - \mathbf{BKM}\mathbf{v}_t)^\top, (\mathbf{w}_{t+1} - \mathbf{AM}\mathbf{v}_t)^\top)^\top$ ，两分量相关，但联合协方差仍有限。两个对角块稳定时，联合齐次系统稳定；用幂级数展开协方差，使得有限初始二阶矩下的二阶矩有界和稳态协方差收敛。非零持续噪声下，状态与预测误差的均值可以趋零，但每次运行仍会受到新噪声扰动，其样本路径一般不会趋于零。有限时域线性二次高斯控制的期望成本最优性由第 15 章另证。受控观测、输入约束、非线性或模型错设可能改变信息与误差动态，不能从这里的谱分离直接推出稳定，更不能直接推出最优。

14.3 策略的调节与跟踪

前面的反馈围绕原点设计，但温度通常要维持在非零设定值，机械位置也可能要跟随持续移动的目标。两类任务都能转化为误差系统的稳定问题，区别在于维持目标所需的输入是常数还是随时间变化。转化前必须先核对目标本身是否符合系统规律。

14.3.1 固定目标下的轨迹调节

14.3.1.1 目标平衡与可行输入

设定值 (setpoint) 是希望状态或输出最终保持的常数。调节 (regulation) 要求偏离该常数的误差趋于零；它不要求在某一时刻经过目标。

定义 14.14 目标平衡与调节误差 对 $\mathbf{x}_{t+1} = \mathbf{A}\mathbf{x}_t + \mathbf{B}\mathbf{u}_t$, 状态设定值 $\mathbf{r}$ 与常值输入 $\mathbf{u}^r$ 构成目标平衡, 若

$$(\mathbf{I} - \mathbf{A})\mathbf{r} = \mathbf{B}\mathbf{u}^r. \quad (14.24)$$

状态调节误差定义为 $\mathbf{e}_t = \mathbf{x}_t - \mathbf{r}$ 。若只指定输出设定值 $\mathbf{q}$, 还需寻找平衡状态 $\mathbf{r}$ 使 $\mathbf{C}\mathbf{r} = \mathbf{q}$, 输出误差为 $\mathbf{e}_t^y = \mathbf{C}\mathbf{x}_t - \mathbf{q}$ 。有输入、状态限制时, 目标平衡还须满足 $\mathbf{u}^r \in U, \mathbf{r} \in S$ 。

对只指定输出的任务, 可解联立方程

$$\begin{bmatrix} \mathbf{I} - \mathbf{A} & -\mathbf{B} \\ \mathbf{C} & \mathbf{0} \end{bmatrix} \begin{bmatrix} \mathbf{r} \\ \mathbf{u}^r \end{bmatrix} = \begin{bmatrix} \mathbf{0} \\ \mathbf{q} \end{bmatrix}.$$

方程可能无解或有多个解; 输出达到设定值也不自动要求所有内部状态相同。连续时间的平衡条件相应为 $\mathbf{A}\mathbf{r} + \mathbf{B}\mathbf{u}^r = \mathbf{0}$ 。这些平衡方程是任务可行性的检查, 不是稳定性证明。

示例 14.15 非零温度需要维持输入 在无噪声温度模型中, 设定值 $r = 2$ 要求 $2 = 0.8 \times 2 + u^r$, 所以 $u^r = 0.4$ 。若直接使用 $u_t = -0.3(x_t - 2)$, 在 $x_t = 2$ 处输入变成零, 下一步温差便降为 1.6, 因而 2 不是闭环平衡。若执行器要求 $0 \leq u \leq 1$, 单从平衡输入看, $u^r = 0.2r$ 允许 $0 \leq r \leq 5$; 再加状态限制 $0 \leq x \leq 3$, 则目标必须落在 $[0, 3]$ 。 $r = 2, u^r = 0.4$ 满足这两项必要条件。从某个初态走到目标期间是否也满足约束, 还需检查整段闭环轨迹。

14.3.1.2 基于误差反馈的轨迹调节

平衡输入抵消目标位置的自然漂移, 反馈只负责消除偏差。对已求得的平衡对取

$$\mathbf{u}_t = \mathbf{u}^r - \mathbf{K}(\mathbf{x}_t - \mathbf{r}), \quad \mathbf{e}_{t+1} = (\mathbf{A} - \mathbf{BK})\mathbf{e}_t. \quad (14.25)$$

第二式由原动态减去平衡方程得到。只要闭环矩阵稳定, $\mathbf{e}_t \rightarrow \mathbf{0}$, 便有 $\mathbf{x}_t \rightarrow \mathbf{r}$ 与 $\mathbf{u}_t \rightarrow \mathbf{u}^r$ 。如果输出目标通过 $\mathbf{C}\mathbf{r} = \mathbf{q}$ 定义, 也有 $\mathbf{e}_t^y = \mathbf{C}\mathbf{e}_t \rightarrow \mathbf{0}$ 。

温度反馈的完整计算为

$$u_t = 0.4 - 0.3(x_t - 2), \quad e_{t+1} = 0.5e_t, \quad e_t = 0.5^t(x_0 - 2). \quad (14.26)$$

从 $x_0 = 0$ 出发, 状态依次为 0, 1, 1.5, 1.75, ..., 输入依次为 1, 0.7, 0.55, 0.475, ...。状态趋于 2 而输入趋于 0.4, 不是输入也必须趋零。

若改用估计状态 $\hat{\mathbf{x}}_t$, 令 $\mathbf{e}_t^0 = \mathbf{x}_t - \hat{\mathbf{x}}_t$, 则调节误差成为 $\mathbf{e}_{t+1} = (\mathbf{A} - \mathbf{BK})\mathbf{e}_t + \mathbf{BK}\mathbf{e}_t^0$. 确定性估计误差趋零、调节闭环稳定时, 卷积展开仍给出调节误差趋零; 估计噪声持续存在时, 只能据噪声条件讨论均值、协方差或误差范围。对 $\mathbf{e}_t$ 与 $\mathbf{u}_t - \mathbf{u}^r$ 使用 LQR 也是一种增益选择, 但权重表达的是任务偏好, 怎样比较不同累计代价由第 15 章展开。达到设定值这一任务本身并未指定哪组权重。

14.3.1.3 持续扰动下的轨迹调节

平衡偏移的计算依赖模型准确。若真实系统含持续加性项 $\mathbf{d}_t$, 误差满足

$$\mathbf{e}_{t+1} = \mathbf{F}\mathbf{e}_t + \mathbf{d}_t, \quad \mathbf{F} = \mathbf{A} - \mathbf{BK}. \quad (14.27)$$

这正是第 13.3 节的受迫响应: 初始误差按 $\mathbf{F}^t$ 衰减, 新扰动却在每一步进入。若 $\|\mathbf{F}^j\| \leq M\rho^j$, $0 < \rho < 1$ 且 $\|\mathbf{d}_t\| \leq \bar{d}$, 则

$$\|\mathbf{e}_t\| \leq M\rho^t\|\mathbf{e}_0\| + \frac{M(1-\rho^t)}{1-\rho}\bar{d}.$$

常值扰动 $\mathbf{d}$ 通常留下 $\mathbf{e}_\infty = (\mathbf{I} - \mathbf{F})^{-1}\mathbf{d}$, 不能靠初始误差衰减消除。温度例为 $\mathbf{e}_{t+1} = 0.5\mathbf{e}_t + \mathbf{d}$, 稳态偏差是 $2\mathbf{d}$ 。若改为独立高斯 $w_{t+1} \sim \mathcal{N}(0, 0.04)$, 均值误差衰减, 但 $\text{Var}(\mathbf{e}_t) \rightarrow 0.04/(1 - 0.5^2) = 0.053\bar{3}$; 二阶矩有界不是样本路径趋于零。

对未知常值偏差, 可以让控制器累积过去的误差, 并据此继续调整输入。积分调节 (integral regulation) 正是把这段记忆作为额外状态。只要输出误差仍非零, 积分状态就会继续变化, 控制器因而不会停留在原来的错误平衡上。对输出误差 $\mathbf{C}\mathbf{x}_t - \mathbf{q} = \mathbf{C}\mathbf{e}_t$ 取

$$\begin{aligned} \mathbf{z}_{t+1} &= \mathbf{z}_t + \mathbf{C}\mathbf{e}_t, \\ \mathbf{u}_t &= \mathbf{u}^r - \mathbf{K}_x\mathbf{e}_t - \mathbf{K}_i\mathbf{z}_t. \end{aligned} \quad (14.28)$$

其中 $\mathbf{z}_t \in \mathbb{R}^p$ 为积分状态; 采样周期不为 1 时, 可将周期因子并入积分增益。增广误差系统为

$$\begin{bmatrix} \mathbf{e}_{t+1} \\ \mathbf{z}_{t+1} \end{bmatrix} = \underbrace{\begin{bmatrix} \mathbf{A} - \mathbf{BK}_x & -\mathbf{BK}_i \\ \mathbf{C} & \mathbf{I} \end{bmatrix}}_{\mathbf{F}_{\text{aug}}} \begin{bmatrix} \mathbf{e}_t \\ \mathbf{z}_t \end{bmatrix} + \begin{bmatrix} \mathbf{d} \\ \mathbf{0} \end{bmatrix}.$$

若 $\mathbf{F}_{\text{aug}}$ 稳定, 则在常值 $\mathbf{d}$ 下收敛到唯一平衡; 该平衡的积分方程强制 $\mathbf{C}\mathbf{e}_\infty = \mathbf{0}$ 。消除的是指定输出的常值误差, 不一定是整个状态误差。

积分状态会保留累积误差，自身带有特征值 1。加入它以后，原反馈稳定也不足以保证整个系统稳定。因此，设计增益前应检查下面的增广矩阵对是否可稳定：

$$\left(\begin{bmatrix} A & 0 \\ C & I \end{bmatrix}, \begin{bmatrix} B \\ 0 \end{bmatrix} \right)$$

除原系统的危险模式必须可控外，新加入的 $\lambda = 1$ 模式要求

$$\text{rank} \begin{bmatrix} I - A & -B \\ C & 0 \end{bmatrix} = n + p.$$

这是增广 PBH 判据在 1 处的展开；对 $\lambda \neq 1$ ，积分状态块可消元，便回到原系统的判据。受约束时还要检查真实扰动下是否存在允许的平衡输入。

示例 14.16 温度系统的积分增广 取 $e_t = x_t - 2$ 、 $z_{t+1} = z_t + e_t$ 与 $u_t = 0.4 - 0.3e_t - 0.1z_t$ 。常值扰动 d 下，

$$\begin{bmatrix} e_{t+1} \\ z_{t+1} \end{bmatrix} = \begin{bmatrix} 0.5 & -0.1 \\ 1 & 1 \end{bmatrix} \begin{bmatrix} e_t \\ z_t \end{bmatrix} + \begin{bmatrix} d \\ 0 \end{bmatrix}.$$

特征多项式为 $\lambda^2 - 1.5\lambda + 0.6$ ，两根 $0.75 \pm 0.19365i$ 的模为 $\sqrt{0.6} < 1$ 。因而 $e_t \rightarrow 0, z_t \rightarrow 10d, u_t \rightarrow 0.4 - d$ 。若 $0 \leq u \leq 1$ ，平衡输入要求 $-0.6 \leq d \leq 0.4$ ；这个条件仍不保证任意初始积分状态的瞬态输入都不饱和。

输入饱和后，真实误差不再服从上述线性增广方程，积分状态却可能继续累积，造成解除饱和后的大幅动作。限制或回退积分累积是常见的抗积分饱和处理，但处理后的闭环仍需重新验证。积分器针对常值偏差的消除能力也不能推广为对任意有界时变扰动的零误差保证。若增广系统稳定，时变有界扰动仍可通过其卷积获得有界误差；若需保证安全，应进一步按第 14.4 节检查实际输入。

14.3.2 运动参考下的轨迹跟踪

14.3.2.1 参考轨迹与可实现条件

跟踪 (tracking) 以随时间变化的状态 r_t 或输出 q_t 为目标，要求 $x_t - r_t$ 或 $Cx_t - q_t$ 趋零或保持在规定范围内。参考本身可以持续运动，因此不能把跟踪收敛写成状态必须趋于某个固定点。

定义 14.17 可实现参考 离散线性系统的参考状态、参考输入为 $(\mathbf{r}_t, \mathbf{u}_t^r)$ 。若每一步满足

$$\mathbf{r}_{t+1} = \mathbf{A}\mathbf{r}_t + \mathbf{B}\mathbf{u}_t^r, \quad \mathbf{q}_t = \mathbf{C}\mathbf{r}_t, \quad (14.29)$$

且参考状态、输入满足所声明的约束，称它为可实现参考。精确从首时刻跟踪还要求 $\mathbf{x}_0 = \mathbf{r}_0$ 。连续时间则要求 $\mathbf{r}_t$ 绝对连续，并有 $\dot{\mathbf{r}}_t = \mathbf{A}\mathbf{r}_t + \mathbf{B}\mathbf{u}_t^r$ 几乎处处成立。

若只给输出曲线，需要先找与其一致的内部状态和输入；不同实现可能具有不同内部行为。有输入变化率、采样周期或执行器动态限制时，也必须把这些约束加入可实现性检查。离散模型能在一步改变参考，并不表示连续执行器能瞬时跳跃。有界参考也未必满足输入限制，例如温度从 $r_t = 0$ 要求下一步到 $r_{t+1} = 2$ ，需 $u_t^r = 2$ ，违反 $u \leq 1$ ；从 3 要求一步降至 0 则需 $u_t^r = -2.4$ ，仅能加热的执行器无法实现。

温度参考的前馈输入由系统方程直接给出：

$$u_t^r = r_{t+1} - 0.8r_t. \quad (14.30)$$

前馈 (feedforward) 是由已知目标运动与模型预先计算的动作，不靠当前误差产生。式中需要 r_{t+1} ，因而假设下一参考已由计划给出；若只有当前目标而无预告，不能直接假装拥有这个信息。对 $r_t = 2 + 0.4 \sin(\pi t/8)$ ，前馈是 $0.4 + 0.4[\sin(\pi(t+1)/8) - 0.8 \sin(\pi t/8)]$ 。其值位于约 $[0.239, 0.561]$ ，参考状态位于 $[1.6, 2.4]$ ，所以参考本身满足 $0 \leq u \leq 1, 0 \leq x \leq 3$ 。但从远离参考的初态出发，纠偏动作仍可能超限。

14.3.2.2 基于前馈与反馈的轨迹跟踪

单独执行前馈能维持准确的参考，却不会主动压低初始偏差。对可实现参考，取

$$\mathbf{u}_t = \mathbf{u}_t^r - \mathbf{K}\mathbf{e}_t, \quad \mathbf{e}_t = \mathbf{x}_t - \mathbf{r}_t, \quad \mathbf{e}_{t+1} = (\mathbf{A} - \mathbf{B}\mathbf{K})\mathbf{e}_t. \quad (14.31)$$

相减时参考运动被前馈精确抵消，留下与调节相同的误差动态。闭环矩阵稳定便保证误差趋零，即使 $\mathbf{r}_t$ 一直振荡。连续时间取相同形式，则有 $\dot{\mathbf{e}}_t = (\mathbf{A} - \mathbf{B}\mathbf{K})\mathbf{e}_t$ 。

温度例使用 $u_t = r_{t+1} - 0.8r_t - 0.3(x_t - r_t)$ ，得到 $e_{t+1} = 0.5e_t$ 。图 14.2 固定同一初态 $x_0 = 0$ 、同一增益 0.3，比较 $r_t = 2$ 与上述正弦参考。两者误差均为 $-2(0.5)^t$ ，但跟踪输入随参考运动持续变化。图中暂不施加输入约束：正弦参考的首个动作约为 1.153，后文将说明安全修正会怎样改变这段误差响应。




图 14.2 同一无噪声温度模型、初态 $x_0 = 0$ 与误差增益 0.3 下的调节和跟踪。左列固定 $r_t = 2$ ，右列取 $r_t = 2 + 0.4 \sin(\pi t/8)$ ；上排比较参考与实际状态，下排比较维持参考的前馈与完整输入。两种任务的误差均为 $e_t = -2(0.5)^t$ ，但运动参考需要持续变化的前馈。图中输入无幅值限制，右下首个动作超过 1，因此此图不是受限执行器的安全证明。离散点之间连线仅便于阅读。

误差趋零、误差有界与始终不超过某阈值仍有区别。无扰动时, $|e_t| = 0.5^t |e_0|$ 既给出收敛, 也给出从首步起的范围; 一般多维稳定矩阵可能先放大误差, 需要使用 $M\rho^t$ 而不能省掉 M 。只证明 $\sup_t \|e_t\| < \infty$ 不说明误差是否足够小。参考位于安全集内也不保证实际状态安全, 必须把参考与误差范围相加后再核对约束。

14.3.2.3 扰动与模型偏差下的轨迹跟踪

真实动态与参考规划常有偏差。设实际系统为 $\mathbf{x}_{t+1} = (\mathbf{A} + \Delta\mathbf{A})\mathbf{x}_t + (\mathbf{B} + \Delta\mathbf{B})\mathbf{u}_t + \mathbf{d}_t$, 名义参考的实现残差为 $\boldsymbol{\eta}_t = \mathbf{A}\mathbf{r}_t + \mathbf{B}\mathbf{u}_t^r - \mathbf{r}_{t+1}$ 。沿用名义前馈加反馈后, 误差的完整方程为

$$\begin{aligned} \mathbf{e}_{t+1} &= (\mathbf{F} + \Delta\mathbf{A} - \Delta\mathbf{B}\mathbf{K})\mathbf{e}_t \\ &\quad + \Delta\mathbf{A}\mathbf{r}_t + \Delta\mathbf{B}\mathbf{u}_t^r + \boldsymbol{\eta}_t + \mathbf{d}_t, \quad \mathbf{F} = \mathbf{A} - \mathbf{B}\mathbf{K}. \end{aligned} \quad (14.32)$$

偏差既改变误差反馈矩阵, 也使原先可实现的参考变成受迫误差来源。因此只验证名义 $\mathbf{F}$ 稳定, 还不足以覆盖任意模型误差。

固定一种向量范数及相容矩阵范数, 假设 $\|\mathbf{F}\| \leq \rho < 1$, $\|\Delta\mathbf{A} - \Delta\mathbf{B}\mathbf{K}\| \leq \varepsilon$ 且 $q := \rho + \varepsilon < 1$ 。稳定矩阵可以在适当范数中取得收缩界, 但偏差界和以下所有大小必须在同一范数下计算, 不能混用欧氏范数数值。若 $\|\mathbf{r}_t\| \leq R_0$, $\|\mathbf{u}_t^r\| \leq U_0$, 且 $\|\boldsymbol{\eta}_t\| \leq \bar{\eta}$, $\|\mathbf{d}_t\| \leq \bar{d}$, 令 $D = \|\Delta\mathbf{A}\|R_0 + \|\Delta\mathbf{B}\|U_0 + \bar{\eta} + \bar{d}$, 则

$$\|\mathbf{e}_t\| \leq q^t \|\mathbf{e}_0\| + \frac{1 - q^t}{1 - q} D. \quad (14.33)$$

证明只需由式 (14.32) 取范数, 再展开 $\|\mathbf{e}_{t+1}\| \leq q\|\mathbf{e}_t\| + D$ 的几何级数。若受迫项趋零且齐次误差仍稳定, 误差也趋零; 若受迫项仅有界, 一般只能保证 $\limsup_t \|\mathbf{e}_t\| \leq D/(1 - q)$ 。积分器可消除合适模型下的常值输出偏差, 不能无条件抵消任意运动参考产生的时变失配。

在精确温度模型中, 若 $|d_t| \leq 0.1$, 则 $|e_t| \leq 0.5^t |e_0| + 0.2(1 - 0.5^t)$ 。若希望误差始终位于 $[-\delta, \delta]$, 应检查 $|e_0| \leq \delta$ 及 $0.5\delta + 0.1 \leq \delta$, 而不只报告最终误差界。对前述正弦参考, 选择 $\delta = 0.6$ 时, 实际状态落在 $[1.0, 3.0]$, 输入落在约 $[0.059, 0.741]$; 在这个误差范围内, 参考加上误差仍满足状态约束, 前馈加上反馈也满足输入约束。这就给出了跟踪与安全同时成立的一组局部条件。图中的 $e_0 = -2$ 不在这个范围, 不能套用这项保证。

如果安全控制器把名义动作改为 $\mathbf{u}_t = \mathbf{u}_t^r - \mathbf{K}\mathbf{e}_t + \Delta\mathbf{u}_t^s$, 精确模型的误差方程还多出 $\mathbf{B}\Delta\mathbf{u}_t^s$ 。修正有界时可并入误差界; 修正逐渐消失时可恢复无扰动的渐近跟踪。若目标与安全约束冲突, 修正可能始终不消失, 此时必须保留安全并承认跟踪目标不可实现, 不能同时宣称两项保证。

14.4 策略的约束与安全

即使控制器能使误差最终变小，纠偏过程中仍可能越界。现在固定允许状态与输入范围，把每一步可行的动作连接到整段轨迹的安全性，再用这些条件修正调节或跟踪动作。安全条件决定能选什么，性能准则决定在其中选哪个；二者须分别验证。

14.4.1 状态约束下的安全区域

一个制动系统最终停下，仍可能在停下之前越过位置边界；平均成本很小的随机系统，也可能有不可接受的少数路径。安全集合（safe set）直接规定允许出现的状态。对确定性离散闭环 $\mathbf{x}_{t+1} = F_k(\mathbf{x}_t)$ ，集合 S 安全保持的条件为

$$F_k(S) \subseteq S. \quad (14.34)$$

从 $\mathbf{x}_0 \in S$ 出发，应用一步条件得到 $\mathbf{x}_1 \in S$ ，归纳便有所有 $\mathbf{x}_t \in S$ 。反之，若要求 S 内每个初态均不离开 S ，特别考察其第一步，就得到上述包含关系。因此它对确定性离散闭环既充分又必要。

例如 $x_{t+1} = x_t + u_t$ 的安全集合为 $[0, \infty)$ 。反馈 $u_t = -1.5x_t$ 给 $x_{t+1} = -0.5x_t$ ，虽然幅值趋零，却使任意 $x_0 > 0$ 在第一步越界； $u_t = -0.5x_t$ 给 $x_{t+1} = 0.5x_t$ ，既稳定又保持非负。图 14.3 保留这一对照，应观察整段轨迹，而不只看最终状态。原系统能到达负半轴也只说明可达，不说明所选闭环应当到达那里。




图 14.3 教学系统 $x_{t+1} = x_t + u_t$ 从 $x_0 = 1$ 出发。蓝色圆点采用 $u_t = -0.5x_t$ ，保持 $x_t \geq 0$ ；红色方点采用 $u_t = -1.5x_t$ ，第一步进入禁止的负半轴后交替衰减。两者都渐近稳定，只有前者保持安全集合。灰色区域表示禁止状态。

连续时间还需保证两个观测时刻之间也不越界。考虑控制仿射系统

$$\dot{\mathbf{x}}_t = \mathbf{f}(\mathbf{x}_t) + \mathbf{G}(\mathbf{x}_t)\mathbf{u}_t, \quad \mathbf{u}_t \in U, \quad (14.35)$$

其中 $\mathbf{x}_t \in \mathbb{R}^n$, $\mathbf{u}_t \in \mathbb{R}^m$, $\mathbf{G}(\mathbf{x}) \in \mathbb{R}^{n \times m}$ 。假设 $\mathbf{f}, \mathbf{G}$ 局部 Lipschitz, 且所选反馈给出存在且唯一的闭环解。以 C^1 函数 h 表示安全集合

$$S = \{\mathbf{x} : h(\mathbf{x}) \geq 0\}. \quad (14.36)$$

定义 14.18 正向不变集 若任意 $\mathbf{x}_0 \in S$ 所产生的闭环解, 在其存在的全部未来时刻均位于 S , 称 S 对该闭环正向不变 (forward invariant)。

这是定义 13.12 在可选择输入的系统中的应用: 本节需要设计使集合保持不变的反馈, 而不是只分析已给定规律。若要说“所有 $t \geq 0$ ”, 还必须排除有限时间解爆破。

若边界 $\partial S = \{h = 0\}$ 光滑且其上 $\nabla h \neq \mathbf{0}$, 内侧对应 h 增大的方向。Nagumo 边界条件要求闭环速度指向内侧或与边界相切:

$$\nabla h(\mathbf{x})^\top [\mathbf{f}(\mathbf{x}) + \mathbf{G}(\mathbf{x})\mathbf{u}] \geq 0 \quad \text{当 } h(\mathbf{x}) = 0. \quad (14.37)$$

在闭集、正则边界和适定闭环等条件下, 它给出正向不变判据。边界梯度退化时不能机械沿用这条光滑表达, 应检查真实切锥。控制器还需要在接近边界时就限制动作, 下面把边界条件扩展到集合附近。

14.4.2 安全条件下的可行动作

函数 h 只用符号区分安全与否, 不必等于几何距离。动作是否安全取决于 h 沿速度的变化, 链式法则给出

$$L_{\mathbf{f}}h(\mathbf{x}) = \nabla h(\mathbf{x})^\top \mathbf{f}(\mathbf{x}), \quad L_{\mathbf{G}}h(\mathbf{x}) = \nabla h(\mathbf{x})^\top \mathbf{G}(\mathbf{x}).$$

它们称为 Lie 导数 (Lie derivative), 分别表示无控制漂移与控制方向对安全函数变化率的贡献。本章的扩展类 $\mathcal{K}$ 函数指连续、严格递增、局部 Lipschitz 且 $\alpha(0) = 0$ 的 $\alpha: \mathbb{R} \rightarrow \mathbb{R}$; 例如 $\alpha(r) = \gamma r, \gamma > 0$ 。局部 Lipschitz 条件用于标量比较系统的唯一性。

在安全区域内部, 控制器可以允许 h 减小, 使状态接近边界, 但要限制减小速度; 到达边界 $h = 0$ 时, 则必须禁止 h 继续减小。下式用 $-\alpha(h)$ 同时表达这两项要求。

定义 14.19 零化控制屏障函数 若在包含 S 的开区域 D 中, 每个状态都存在 $\mathbf{u} \in U$ 使 $L_f h(\mathbf{x}) + L_G h(\mathbf{x})\mathbf{u} \geq -\alpha(h(\mathbf{x}))$, 则称 h 为该区域上的零化控制屏障函数 (control barrier function, CBF)。其上确界表达为

$$\sup_{\mathbf{u} \in U} \{L_f h(\mathbf{x}) + L_G h(\mathbf{x})\mathbf{u}\} \geq -\alpha(h(\mathbf{x})), \quad (14.38)$$

并要求有实际动作满足该阈值; 特别是上确界恰等于阈值时, 必须能够取到。

CBF 把“留在区域内”变成每个状态可检查的动作不等式。当 U 紧且动作函数连续时, 上确界可取到, 数值不等式就足够; 对非紧 U , 若上确界严格大于阈值, 也能选到满足阈值的动作, 不必要求无穷大的上确界被取到。真正需要的是以下集合非空:

$$K_{\text{cbf}}(\mathbf{x}) = \{\mathbf{u} \in U : L_f h(\mathbf{x}) + L_G h(\mathbf{x})\mathbf{u} \geq -\alpha(h(\mathbf{x}))\}. \quad (14.39)$$

执行器约束已经通过 $\mathbf{u} \in U$ 取交集, 不能先忽略输入上限设计动作, 再默认饱和后的动作仍符合屏障条件⁵。

定理 14.20 CBF 条件保证正向不变 设式 (14.35) 及安全函数满足上述正则条件。若反馈 $\mathbf{u} = \kappa(\mathbf{x})$ 局部 Lipschitz, 并在包含 S 的开区域 D 中始终满足 $\kappa(\mathbf{x}) \in K_{\text{cbf}}(\mathbf{x})$, 则 S 在相应闭环解存在的时间区间内正向不变。

证明. 沿任意闭环解记 $r_t = h(\mathbf{x}_t)$, 链式法则和 CBF 约束给出 $\dot{r}_t \geq -\alpha(r_t)$ 。考虑比较系统

$$\dot{z}_t = -\alpha(z_t), \quad z_0 = r_0 \geq 0.$$

α 局部 Lipschitz, 比较系统局部解唯一, 且 $z = 0$ 是平衡解; 从非负初值出发的解不能穿过零点。又因 α 严格递增且 $\alpha(0) = 0$, z_t 留在 $[0, z_0]$ 内, 所以比较解在任意有限时间存在。为验证微分不等式中的 r_t 也不低于 z_t , 在轨迹位于 D 的任一紧时间区间上, 取 α 在两条标量轨迹值域所在紧区间的 Lipschitz 常数 L , 并令 $q_t = \max\{z_t - r_t, 0\}$ 。在 $z_t > r_t$ 处,

$$\dot{q}_t = \dot{z}_t - \dot{r}_t \leq -\alpha(z_t) + \alpha(r_t) \leq Lq_t.$$

正部函数绝对连续, 且在其零集上导数几乎处处为零, 故这个不等式几乎处处成立。由 $q_0 = 0$ 可得 $q_t \leq L \int_0^t q_s ds$; 引理 13.4 遂给出 $q_t = 0$, 即 $r_t \geq z_t \geq 0$ 。因为 D 是包含 S 的开区域, 若轨迹离开 S , 必先在 D 中穿过 $h = 0$ 进入 $h < 0$, 与比较不等式矛盾。故在闭环解存在的全部时间内, $\mathbf{x}_t \in S$ 。

⁵ A. D. Ames, X. Xu, J. W. Grizzle, P. Tabuada, *Control Barrier Function Based Quadratic Programs for Safety Critical Systems* In IEEE Transactions on Automatic Control, 2017, vol. 62, no. 8, pp. 3861–3876

对 $\alpha(r) = \gamma r$ 还可以直接验证:

$$\frac{d}{dt}(e^{\gamma t} r_t) = e^{\gamma t}(\dot{r}_t + \gamma r_t) \geq 0.$$

所以 $r_t \geq e^{-\gamma t} r_0 \geq 0$ 。当 $r = 0$ 时约束退化为 $\dot{r} \geq 0$, 与边界条件一致。 ■

这项证明依赖动作约束始终可行、反馈与动态足够规则, 以及动作按连续时间模型实际施加。某一个采样点的动作朝内, 不能代替这些沿轨迹的条件。

回到离散温度系统, 令 $S = [0, 3], U = [0, 1]$ 且无噪声。下一步安全要求 $0 \leq 0.8x + u \leq 3$, 因此精确的一步安全动作集合为

$$K_{\text{safe}}(x) = [\max\{0, -0.8x\}, \min\{1, 3 - 0.8x\}]. \quad (14.40)$$

对 $x \in [0, 3]$, 下端为 0, 上端至少为 0.6, 所以每个安全状态都有可行动作。固定目标反馈 $u = 0.4 - 0.3(x - 2) = 1 - 0.3x$ 在该区间取值于 $[0.1, 1]$, 下一状态为 $1 + 0.5x \in [1, 2.5]$ 。它不需要修正就同时实现输入可行、状态安全与趋于 2。这个显式包含关系比“反馈稳定”多证明了整个区间的安全保持。

14.4.3 可行约束下的反馈修正

若调节或跟踪给出的名义动作 $\mathbf{u}_{\text{nom}}$ 不可行, 可以在每个状态寻找对它修改最小的安全动作:

$$\begin{aligned} \mathbf{u}^*(\mathbf{x}) \in \arg \min_{\mathbf{u} \in U} \quad & \frac{1}{2}(\mathbf{u} - \mathbf{u}_{\text{nom}})^\top \mathbf{H}(\mathbf{u} - \mathbf{u}_{\text{nom}}) \\ \text{s.t.} \quad & L_f h(\mathbf{x}) + L_G h(\mathbf{x}) \mathbf{u} \geq -\alpha(h(\mathbf{x})), \end{aligned} \quad (14.41)$$

其中 $\mathbf{H} > \mathbf{0}$ 规定修改各输入分量的代价。CBF 约束对输入线性; U 为多面体时这是二次规划 (quadratic program, QP), 一般非空闭凸 U 则给出闭凸约束下的二次优化问题。第 4 章的约束优化工具可用于计算它。目标只比较当前动作的距离, 并不使修正后的整条轨迹保持原 LQR 成本最优。

示例 14.21 一维积分器上的安全投影 考虑 $\dot{x}_t = u_t$ 、 $S = [0, \infty)$ 、 $h(x) = x$ 及 $\alpha(h) = \gamma h$ 。CBF 条件为 $u \geq -\gamma x$ 。若 $U = \mathbb{R}, H = 1$, 解为

$$u^*(x) = \max\{u_{\text{nom}}(x), -\gamma x\}. \quad (14.42)$$

在 $x = 0.2, \gamma = 1$ 且名义动作恒为 $u_{\text{nom}} = -1$ 时, 动作修正为 -0.2 。持续应用该反馈, 状态按 $x_t = 0.2e^{-t}$ 接近零而不穿过边界。若执行

器另要求 $u \leq -0.5$, 此处与 $u \geq -0.2$ 冲突, QP 不可行; 安全函数的形式本身不能保证执行器能够提供所需动作。

在上述凸约束下, 若可行域非空且闭, 正定二次目标在动作范数增大时趋于无穷, 所以极小点存在; 严格凸性保证动作唯一。没有闭性时, 严格凸只说明已有极小点至多一个, 不能保证下确界取到。即使每个状态上的优化问题都有唯一解, 从状态到动作的映射 $\mathbf{x} \mapsto \mathbf{u}^*(\mathbf{x})$ 也未必局部 Lipschitz: 约束梯度退化、活跃约束切换或可行域突变可能破坏正则性。应用不变性定理前, 还需按约束资格条件与参数化优化结果核验反馈的规则性。

示例 14.22 圆形障碍外的安全修正 对平面单积分器 $\dot{\mathbf{p}}_t = \mathbf{u}_t$, 障碍中心为 $\mathbf{c}$ 、半径为 $r > 0$ 。取 $h(\mathbf{p}) = \|\mathbf{p} - \mathbf{c}\|_2^2 - r^2$, 安全区域是圆外。 $\alpha(h) = \gamma h$ 给出

$$2(\mathbf{p} - \mathbf{c})^\top \mathbf{u} \geq -\gamma(\|\mathbf{p} - \mathbf{c}\|_2^2 - r^2). \quad (14.43)$$

在边界 $\mathbf{p} - \mathbf{c} = (r, 0)^\top$, 名义动作 $(-v, 0)^\top, v > 0$ 指向障碍内部, 左侧为 $-2rv < 0$ 。无其他输入约束且 $\mathbf{H} = \mathbf{I}$ 时, QP 将动作投影到半空间 $2(\mathbf{p} - \mathbf{c})^\top \mathbf{u} \geq 0$, 此处修正为 $\mathbf{u}^* = \mathbf{0}$ 。若名义动作含有切向分量, 投影保留切向分量, 只移除向内的法向分量。停在边界是安全的, 却未必能够完成绕行任务。

多个 $h_i(\mathbf{x}) \geq 0$ 会产生多条动作约束。每条单独可行, 不代表它们与执行器限制联合可行; 障碍、制动能力或转向限制可能相互冲突。加入松弛变量使优化器返回数值解, 同时也允许原安全条件被违反, 因而不能再声明原来的硬不变性保证。此时应说明约束冲突后怎样处理、在哪些区域还能恢复安全, 或改为保证多大的越界概率; 不能继续使用原先的硬安全结论。图 14.4 用 (x, u) 平面显示一维投影: 每个固定状态的安全动作是一条竖直半直线, 修正沿这条半直线寻找最近点。




图 14.4 教学积分器 $\dot{x}_t = u_t$ 、安全集合 $x \geq 0$ 及 $\alpha(h) = h$ 。灰色虚线 $u = -x$ 上方为允许动作；蓝色实线为名义动作 $u = -1$ ，红色虚线为投影 $u^* = \max\{-1, -x\}$ 。 $x \geq 1$ 处无需修正， $x = 0.2$ 处修正为 -0.2 。图中没有额外执行器限制，不能据此判断有限输入范围下的联合可行性。

对温度模型，使用式 (14.40) 的闭区间投影：

$$u_t = \min\{u_{\max}(x_t), \max\{u_{\min}(x_t), u_{\text{nom},t}\}\}.$$

前述正弦跟踪从 $x_0 = 0$ 出发，名义首个动作为 $0.4 + 0.4 \sin(\pi/8) + 0.6 \approx 1.153$ ，投影改为 $u_0 = 1$ 。于是 $x_1 = 1$ ，而不是无约束的 1.153；此时 $e_1 = 1 - [2 + 0.4 \sin(\pi/8)] \approx -1.153$ ，不再等于 $0.5e_0 = -1$ 。由于每步安全动作集合非空，重复投影仍保持 $0 \leq x_t \leq 3$ 及 $0 \leq u_t \leq 1$ ，但跟踪误差须按增加了修正项的方程重新分析。目标参考持续要求超出能力的输入时，不能同时保持精确跟踪；安全投影的“最近”也不等于全时域最优。

14.4.4 扰动与离散执行下的安全保证

若真实连续动态含 $\|d_t\|_2 \leq \delta$ 的加性扰动，最坏方向使安全函数的导数减少至多 $\|\nabla h(x)\|_2 \delta$ 。因此鲁棒充分条件为

$$L_f h + L_G h u \geq -\alpha(h) + \|\nabla h\|_2 \delta. \quad (14.44)$$

有有效上界的模型误差可并入同一裕量。没有经过验证的误差界时，任意加一个“安全系数”只是经验缓冲，不能推出鲁棒正向不变性。

离散温度系统若 $|w_{t+1}| \leq \delta$ ，最坏扰动下的安全动作集合为

$$K_{\text{safe}}^\delta(x) = [\max\{0, \delta - 0.8x\}, \min\{1, 3 - \delta - 0.8x\}]. \quad (14.45)$$

当 $0 \leq \delta \leq 0.6$, 该集合对所有 $x \in [0, 3]$ 非空: 下端不超过 1, 未截断区间宽度 $3 - 2\delta$ 非负, 且上端在 $x = 3$ 也不小于零。若 $\delta > 0.6$, 从 $x = 3$ 面对正向最大扰动, 即使取最小输入 $u = 0$ 也会越界, 所以整个 $[0, 3]$ 不能在这类扰动下保持不变。固定目标的名义反馈产生 $1 + 0.5x + w_{t+1}$, 对 $\delta \leq 0.5$ 已经落在 $[0, 3]$, 因而无需修正。高斯噪声没有有限的确幅值界, 不能套用这个逐路径保证; 概率风险要按第 15 章的风险口径另行定义。

数字控制器每隔 Δ 更新动作, 并在区间内保持不变。采样点满足连续 CBF 约束, 不自动保证区间内部满足, 因为状态和安全导数仍在变化。例如对固定保持动作, 若 $g(\mathbf{x}, \mathbf{u}) = L_f h + L_G h \mathbf{u} + \alpha(h)$ 在已核验区域内对状态的 Lipschitz 常数为 L_g , 且速度有界 $\|\dot{\mathbf{x}}\| \leq M$, 则区间内 g 最多降低 $L_g M \Delta$ 。采样时预留这一裕量才可保证区间内 $g \geq 0$; 区域与速度界本身也须有效, 不能假定在尚未证明安全的区域外仍成立。

也可以直接构造离散屏障条件

$$h(\mathbf{x}_{t+1}) - h(\mathbf{x}_t) \geq -\alpha_d(h(\mathbf{x}_t)),$$

并要求每个 $r \geq 0$ 都有 $0 \leq \alpha_d(r) \leq r$ 。这样 $h(\mathbf{x}_t) \geq 0$ 便推出 $h(\mathbf{x}_{t+1}) \geq h(\mathbf{x}_t) - \alpha_d(h(\mathbf{x}_t)) \geq 0$, 可逐步归纳安全性。常用 $\alpha_d(r) = \gamma r$ 取 $0 < \gamma \leq 1$ 。若离散模型只是连续系统的采样映射, 采样点安全仍不等于区间安全, 还需检查采样间轨迹; 在预测时域中直接验证整段连续轨迹是另一种办法。

还有一种限制来自相对阶 (relative degree), 即对某个输出求导多少次, 当前输入才第一次显式出现。若 $L_G h = 0$, 一阶 CBF 约束不含动作。例如双积分器 $\dot{p}_t = v_t, \dot{v}_t = u_t$ 用 $h(p) = p - p_{\min}$ 保护位置下界, 有 $\dot{h} = v$ 、 $\ddot{h} = u$, 因此相对阶为 2。此时需要递归控制更高导数, 或把速度与制动距离纳入安全函数。取 $\psi_1 = v + k_1 h$ ($k_1 > 0$), 若再约束

$$u + k_1 v + k_2 \psi_1 \geq 0, \quad k_2 > 0,$$

则 $\dot{\psi}_1 \geq -k_2 \psi_1$ 。在初态同时满足 $h \geq 0, \psi_1 \geq 0$ 、约束始终可行且闭环适时时, 比较原理先保证 $\psi_1 \geq 0$, 再由 $\dot{h} \geq -k_1 h$ 保证 $h \geq 0$ 。新增的速度条件不可省略, 执行器幅值也可能使这条高阶约束不可行。

例如 $p - p_{\min} = 0.1, v = -1$, 最大制动加速度为 2, 最快停止距离 $v^2/(2u_{\max}) = 0.25$ 已超过剩余距离。此时位置虽在允许区间, 任何允许动作也不能避免后续越界。安全初态应同时考虑位置与速度; 把一阶公式套到 $L_G h = 0$ 处, 只会得到与输入无关的条件。

CBF 还要求用于计算约束的状态信息可靠。若只有估计值, 应先给估计误差集合界或概率模型, 再收紧安全集合或构造输出反馈屏障。把估计均值直接当作真实状态代入, 只能验证估计轨迹, 不能从有界误差协方差自动推出真实轨迹的硬安全。

14.5 本章小结

一个可实施策略既要遵守信息时序，也要符合执行器能够改变的方向。可控、可观测要求处理全部状态方向；可稳定要求输入无法影响的模式已经稳定，可检测要求观测无法区分的误差模式能够自行衰减。它们为设计提供结构条件，真正的轨迹行为仍由闭环矩阵、误差动态或 Lyapunov 不等式决定。增益还会改变输入幅值和中间阶段的响应，所以不同稳定反馈并非可以不加区别地互换。

在同一温度模型中，固定目标 2 需要平衡输入 0.4，再加本章选取的误差反馈，才得到 $e_{t+1} = 0.5e_t$ 。运动参考改用 $u_t^r = r_{t+1} - 0.8r_t$ 抵消参考变化，同一个稳定误差系统便能服务于跟踪。常值扰动、时变扰动和模型偏差改变这一结论：合适的积分增广可以消除常值输出偏差，对一般的持续扰动，通常只能给出误差范围，非零随机噪声则应区分均值收敛、协方差有界与路径收敛。

Riccati 方法在特定二次成本下选择反馈。有限时域的逐步配方保持二次形式；确定性无折扣无限时域还需可稳定、成本可检测及权重条件，才能同时得到稳定化与成本最优性。输出反馈通过估计连接实际信息，确定性系统中分开设计反馈与观测器的谱结论，以及随机系统中的稳态误差结论，各有适用条件，不能把它们推广成任意观测、约束或模型失配下的保证。

安全性约束全过程。对无噪声温度系统，固定目标反馈已经保持 $0 \leq u \leq 1, 0 \leq x \leq 3$ ；同一增益的运动参考却可能在初始纠偏时要求过大输入。一步安全集合或连续屏障约束可以修正动作，但修正后的调节、跟踪与价值必须重新核验。约束不可行、扰动无有效上界、采样间行为未检查或状态估计不可靠时，都不能沿用名义安全结论。第 15 章将进一步比较这些策略的累计成本、收益与风险；目标可达、误差收敛、轨迹安全和价值最优仍是需要分别回答的问题。

策略的价值与优化

把室温调到目标附近，并没有唯一确定怎样加热。快速升温需要较大的输入，缓慢升温则让人在较长时间内承受温度偏差；有随机扰动时，平均成本接近的两项策略，出现严重损失的概率和损失幅度也可能不同。第 14 章已经讨论策略能否实现目标、使误差收敛并保持安全，本章进一步问：怎样给这些策略的后果计价，怎样算出给定策略的价值，又怎样选择成本更低的策略？

评价的对象是策略诱导的状态与行动轨迹。确定性模型中，初态和策略可以确定一条轨迹；随机模型中，它们通常只确定轨迹的分布。因此，要分清一次执行付出的成本、同一策略多次执行的平均成本，以及对损失最大的那一部分结果的评价。先确定对象和评价准则，才能计算价值；计算时固定行动规则，优化时才允许改变规则。这个区别也决定了递推中该对行动概率求和，还是在可选行动中取最小值。

本章以成本最小化为主要约定。若任务使用收益，只需把收益定义为成本的负值，并将最小化与最大化成套转换。路线选择保留一个可以逐项枚举的轨迹分布，温度模型连接前章的反馈设计；信息获取和探索例子则说明行动不仅改变物理状态，也会改变以后知道什么。这些例子最终都要回答同一个问题：在给定信息、模型和评价准则下，哪项可实施策略更合适？

15.1 策略的表示与价值

15.1.1 策略的行动与信息

加热器每次收到的是一个输入值，控制器需要规定的却是整套选择规则：温度偏低时怎样选，下一次读数改变后又怎样选。策略（policy）就是按当时已经知道的信息持续选择行动的规则。它与一条已经执行的行动序列不同；同一策略遇到不同观测，可以产生不同序列。

先用离散时间和有限状态说明信息次序。状态记为 $S_t \in \mathcal{S}$, 行动记为 $A_t \in \mathcal{A}(S_t)$, 每个 $\mathcal{A}(s)$ 均非空。在行动 A_t 发生之前, 完整状态历史为

$$H_t = (S_0, A_0, S_1, \dots, A_{t-1}, S_t).$$

历史依赖随机策略用概率 $\pi_t(a | h_t)$ 指定下一行动, 满足 $\pi_t(a | h_t) \geq 0$ 及 $\sum_a \pi_t(a | h_t) = 1$, 并仅支持当前允许行动。确定性策略将全部质量放在某个行动上。连续行动时使用可测概率核 $\pi_t(da | h_t)$, 而不是对单个实数行动指定密度而忘记可能的原子质量。策略的随机数在使用时产生, 不得包含未来环境噪声的信息。

若策略只读取当前状态, 写作 $\pi_t(a | s)$, 称为 Markov 策略; 若规则还不随时间改变, 写作 $\pi(a | s)$, 称为平稳 Markov 策略。只去掉历史依赖不等于去掉时间依赖: 距离截止时间还有多久, 常会改变合理的动作。前章的开环序列、状态反馈和输出反馈, 分别规定了这些规则怎样接入实际系统, 见定义 14.1。

若只能观察 Y_t , 允许信息是 $\mathcal{I}_t = \sigma(Y_0, A_0, \dots, A_{t-1}, Y_t)$, 策略不能直接读取 S_t 。即使观测与状态同维, 也不能把带噪声读数当作真实状态。第 13 章状态推断给出的条件分布 $b_t(ds) = \mathbb{P}(S_t \in ds | \mathcal{I}_t)$ 汇集了观测历史对当前状态的认识。在模型已知、该分布连同时间足以预测后续观测和成本时, 可以用 b_t 作为决策的状态; 这不是说一次观测 Y_t 本身满足同样条件。

共同温度模型仍为

$$x_{t+1} = 0.8x_t + u_t + w_{t+1}, \quad y_t = x_t + v_t. \quad (15.1)$$

x_t 是相对于环境温度的温差, u_t 是加热量。本章先取 $w_{t+1} = v_t = 0$, 默认 $u_t \in \mathbb{R}$, 不暗加输入限制。目标 $r = 2$ 需要平衡输入 $u^r = 2 - 0.8 \times 2 = 0.4$ 。前章的示例状态反馈

$$u_t = 0.4 - 0.3(x_t - 2) \quad (15.2)$$

使误差 $e_t = x_t - 2$ 满足 $e_{t+1} = 0.5e_t$ 。这说明无噪声时误差收敛, 却还没有给出这项策略的成本。若恢复观测噪声, 式中的 x_t 须可见, 或另行设计基于估计的策略; 直接把 y_t 代入得到的是另一项策略。

15.1.2 策略诱导的轨迹

只有策略还不能预测结果: 同一“走捷径”的规则, 在不同路况模型下产生的终点概率不同。因此需要把初态、行动选择和环境转移连接起来。取有限时域 $t = 0, \dots, H$, 初始分布为 μ_0 , 阶段成本为 $c_t(s, a)$, 终端成本为 $c_H(s)$ 。给定一段以状态 s 结束的历史 h_t , 要求受控转移满足

$$\mathbb{P}(S_{t+1} = s' | H_t = h_t, A_t = a) = P_t(s' | s, a).$$

这个 Markov 条件说的是给定当前状态和行动后, 过去不再提供预测下一状态的额外信息; 成本也已按同样的状态和行动表示。

定义 15.1 有限 Markov 决策过程与策略 有限状态集 $\mathcal{S}$ 、各状态的非空有限行动集 $\mathcal{A}(s)$ 、初始分布 μ_0 、受控转移概率 P_t 、阶段成本 c_t 和终端成本 c_H 组成有限时域 Markov 决策过程 (Markov decision process, MDP)。允许策略可以根据全部已有历史随机选择行动 $\pi_t(a | H_t)$; 只依赖当前状态时为 Markov 策略, 确定选择时记作 $a = \pi_t(s)$ 。

这里 S_t, A_t 分别承担前章状态和输入的角色, 有限 MDP 是便于求和计算的版本; 温度模型的连续状态不属于有限集合。若真实转移或成本还依赖未记录的过去, 必须补充状态信息, 不能只靠给观测改名来获得 Markov 性质¹。

现在固定策略 π 。对一条状态与行动轨迹 $\tau = (s_0, a_0, s_1, \dots, a_{H-1}, s_H)$, 链式法则给出

$$\mathbb{P}^\pi(\tau) = \mu_0(s_0) \prod_{t=0}^{H-1} \pi_t(a_t | h_t) P_t(s_{t+1} | s_t, a_t). \quad (15.3)$$

每个因子都对应实际生成的一步: 先抽初态, 再按当前历史选行动, 再由环境生成下一状态。连续状态时用概率核的逐次积分表达同一构造。输出反馈还要插入观测核, 并让行动核仅依赖已经产生的观测历史; 边缘化看不见的状态后, 才得到控制器所见的数据分布。

先构造一个只有一次选择的路线任务, 便于列出全部可能后果。起点 s_0 选择“稳妥”会确定到达终端损失 2 的状态; 选择“捷径”以概率 0.8 到达损失 0 的状态, 以概率 0.2 到达损失 6 的状态。起点行动的阶段成本为零。这里只有一次行动, $H = 1$: 起点选择路线, 终点结算成本; 终点没有第二次选择。若策略以概率 p 选择捷径, 三条轨迹的概率分别为

$$1 - p, \quad 0.8p, \quad 0.2p.$$

例如 $p = 1/2$ 时为 $(0.5, 0.4, 0.1)$ 。改变 p 改变行动和终点的联合分布, 但没有改变给定行动后的路况概率。策略随机化与环境随机性因此是两个不同来源。

15.1.3 轨迹收益与策略价值

轨迹生成后, 可以给实际经过的状态和行动逐项计价。令阶段收益 $r_t(s, a) = -c_t(s, a)$ 、终端收益 $r_H(s) = -c_H(s)$ 。一条实现轨迹的累计成本和收益为

$$L(\tau) = \sum_{t=0}^{H-1} c_t(s_t, a_t) + c_H(s_H), \quad G(\tau) = -L(\tau). \quad (15.4)$$

¹ M. L. Puterman, *Markov Decision Processes: Discrete Stochastic Dynamic Programming*, Wiley, 1994

二者是轨迹上的数值，不是策略的平均表现。期望准则下，策略成本为 $J^\pi = \mathbb{E}^\pi[L]$ ，策略收益为 $\mathbb{E}^\pi[G] = -J^\pi$ ；有限空间可用式 (15.3) 逐条求和。在期望成本准则下，后文用 V 表示从当前时刻开始的预期剩余成本，也称继续价值，因此 V 越小越好。

运行到中途，已经支付的成本不再改变，但后续行动仍可比较。对一段以状态 s 结束的历史 h_t ，一般历史策略的继续成本定义为

$$J_t^\pi(h_t) = \mathbb{E}_{h_t}^\pi \left[\sum_{k=t}^{H-1} c_k(S_k, A_k) + c_H(S_H) \right]. \quad (15.5)$$

下标 h_t 表示固定已知历史，再用策略和转移核重新生成后续过程。即使该历史在某个初始分布下概率为零，也可以通过这些核定义继续过程，不必对零概率事件直接作比值条件化。Markov 策略下，继续过程只依赖时间与末状态，于是记作 $V_t^\pi(s)$ ；一般历史策略可能在同一状态记住不同经历，不能无条件这样缩写。过去累计成本加上 $J_t^\pi(h_t)$ ，才是该历史下整条轨迹总成本的条件期望。

无限时域中，若阶段成本时不变且 $|c(s, a)| \leq C$ ，取 $0 \leq \gamma < 1$ ，定义

$$V^\pi(s) = \mathbb{E}_s^\pi \left[\sum_{t=0}^{\infty} \gamma^t c(S_t, A_t) \right]. \quad (15.6)$$

这里 π 仍可依赖全部历史， s 指定起点。几何级数给出 $|V^\pi(s)| \leq C/(1-\gamma)$ ，保证累计和与期望有意义。连续状态的二次成本通常无界，需要另证可积性或矩界；不能只因写了折扣就套用该上界。无折扣的无限累计也可能发散，尤其是系统持续支付维持目标所需的能耗时。

为共同温度模型定义具体成本，取教学权重 $\lambda = 1$ ：

$$c(x, u) = (x - 2)^2 + \lambda u^2, \quad c_H(x) = (x - 2)^2. \quad (15.7)$$

第一项惩罚舒适偏差，第二项是按加热幅值平方计价的能耗代理，不声称等于未经标定的实际电费。这里计的是总输入 u ，不是偏移输入 $u - 0.4$ ；两种计价会产生不同的最优策略。阶段收益始终是 $-c(x, u)$ 。从 $x_0 = 0$ 执行式 (15.2) 两次得到 $(u_0, u_1) = (1, 0.7)$ 和 $(x_1, x_2) = (1, 1.5)$ ，这给出了可逐项评价的一条轨迹。固定规则的计算将在第 15.3.1 节完成，届时才与其他规则比较。

只有一次行动时， L 退化为损失 $\ell(a, Y)$ ，收益为 $-\ell(a, Y)$ 。这时概率仍不足以决定行动。例如，判断一个对象是否属于阳性类别，即使已知其阳性概率为 0.3，仍需知道误报和漏判分别付出多大代价，才能比较预测阳性与预测阴性。在对称分类损失与高漏诊损失下，合理行动可能不同。概率只描述结果的可能性，还没有包括后果的代价，更不是多步任务中已经累计

未来后果的继续价值。条件风险和 Bayes 行动的正式求解留在第 15.4.1 节；先固定策略，下一节比较如何汇总它产生的随机成本。

15.2 策略的轨迹价值与风险

15.2.1 平均收益与价值波动

路线策略已经确定，仍有不止一种评价它的办法。固定走稳妥路线的期望损失为 2；固定走捷径的期望损失为 $0.8 \times 0 + 0.2 \times 6 = 1.2$ 。后者的平均收益较高，却有 20% 的概率付出损失 6。比较策略以前，需要明确任务在意平均成本，还是不能承受某些严重后果。本节先不改变策略，只比较这些评价口径。

设随机轨迹损失 L 可积。期望 $\mathbb{E}[L]$ 按发生概率线性汇总所有后果；对应的期望收益为 $-\mathbb{E}[L]$ 。为了看清均值遗漏的信息，再考虑两个教学方案

$$L_{\text{safe}} = 1, \quad L_{\text{tail}} = \begin{cases} 0, & \text{概率} 0.95, \\ 20, & \text{概率} 0.05. \end{cases}$$

二者的期望均为 1，但第二个方案在 95% 的情形中没有损失，全部期望损失都来自最差的 5%。这可以理解为一项已经固定的策略所诱导的终端损失，不能用“平均相同”代替“后果相同”。

有二阶矩时，方差 $\text{Var}(L)$ 衡量围绕均值的二次波动。均值-方差准则为

$$\mathbb{E}[L] + \lambda \text{Var}(L), \quad \lambda \geq 0.$$

其中 λ 表达波动的权重，与温度成本中的输入权重并无必然关系。该准则同时惩罚高于和低于均值的偏离，意外变好也会增加方差。更重要的是，它未必尊重逐场景的损失大小：令 L_1 等概率取 0, 2，令 $L_2 = 2$ ，则 $L_1 \leq L_2$ ，但 $\lambda > 1$ 时

$$\mathbb{E}[L_1] + \lambda \text{Var}(L_1) = 1 + \lambda > 2 = \mathbb{E}[L_2] + \lambda \text{Var}(L_2).$$

这个反例说明，惩罚围绕均值的波动，与重点限制损失最大的那些结果，是不同的要求。

前面的均值-方差反例暴露了一个基本要求：每种情形中的损失都较小，整体风险也应较小。除此以外，我们还可以要求固定增加一笔成本时，风险增加同样数额，并检查按比例承担损失或合并两份损失时，评价是否保持一致。下面把这些要求写成风险泛函的性质，用来判断一种评价办法是否合适。

定义 15.2 相干风险 为了统一比较这些评价办法，用风险泛函 $\rho : L^1(P) \rightarrow \mathbb{R}$ 把一个随机损失转换为一个风险值，风险值越小越好。单调性要求 $L \leq L'$ 几乎处处时 $\rho(L) \leq \rho(L')$ ；平移等变性要求 $\rho(L + m) = \rho(L) + m$ ，其中 m 为确定常数。凸性要求

$$\rho(\tau L + (1 - \tau)L') \leq \tau \rho(L) + (1 - \tau)\rho(L'), \quad 0 \leq \tau \leq 1.$$

若风险泛函具有单调性、平移等变性、正齐次性 $\rho(\lambda L) = \lambda \rho(L)$ ($\lambda \geq 0$) 和次可加性 $\rho(L + L') \leq \rho(L) + \rho(L')$ ，称为相干风险 (coherent risk measure)。

正齐次性和次可加性已经蕴含凸性；单列凸性是为了与后文一般凸风险比较。这里的 $\tau L + (1 - \tau)L'$ 是在同一场景下按比例承担两份损失，不是先掷硬币选一个方案，再完整承担该方案的损失。策略随机化通常对应后者，不能直接套用这个凸性公式。期望满足相干风险的各项性质；均值-方差一般不单调，且需要比可积更强的二阶矩条件。

15.2.2 尾部损失与风险评价

15.2.2.1 基于分位数的风险价值

若任务问“至少 95% 的执行，损失能否控制在某一水平内”，需要的量是损失分位数，不是方差。

定义 15.3 风险价值 对实值随机损失 L 与 $\alpha \in (0, 1)$ ，左 α 分位数为

$$q_\alpha(L) = \inf\{z \in \mathbb{R} : \mathbb{P}(L \leq z) \geq \alpha\}. \quad (15.8)$$

同一量在风险管理中称为风险价值 (value at risk, VaR)，记为 $\text{VaR}_\alpha(L) = q_\alpha(L)$ 。

它给出一个损失阈值，不说明阈值以上的后果有多严重。在前面的等均值例中，

$$\text{VaR}_{0.95}(L_{\text{safe}}) = 1, \quad \text{VaR}_{0.95}(L_{\text{tail}}) = 0.$$

第二式来自 $\mathbb{P}(L_{\text{tail}} \leq 0) = 0.95$ 。分位点恰落在零损失的原子上，不是说损失 20 已经消失。必须说明左分位数约定，否则离散分布的边界容易产生歧义。

VaR 单调且平移等变, 但一般不次可加。设互斥事件 E_1, E_2 各有概率 0.04, 令 $L_i = \mathbb{I}\{E_i\}$ 。在 $\alpha = 0.95$ 时, 两项 VaR 均为零, 而合计损失以概率 0.08 取 1, 所以

$$\text{VaR}_{0.95}(L_1 + L_2) = 1 > \text{VaR}_{0.95}(L_1) + \text{VaR}_{0.95}(L_2) = 0.$$

单独未超过分位概率预算的两项事件, 合并后超过了预算。这个反例否定的是一般次可加性, 不排除特定分布族下可以得到更强的结论。

15.2.2.2 基于尾部平均的条件风险价值

知道尾部从哪里开始, 还不足以区分“稍微超标”和“严重损失”。条件风险价值 (conditional value at risk, CVaR) 平均最坏的 $1 - \alpha$ 概率质量²。

² R. T. Rockafellar, S. Uryasev, *Optimization of Conditional Value-at-Risk* In *The Journal of Risk*, 2000, vol. 2, no. 3, pp. 21–41

定义 15.4 条件风险价值 对 $L \in L^1(P)$ 和 $\alpha \in (0, 1)$, 定义

$$\text{CVaR}_\alpha(L) = \inf_{\eta \in \mathbb{R}} \left\{ \eta + \frac{1}{1 - \alpha} \mathbb{E}[(L - \eta)_+] \right\}, \quad (z)_+ = \max\{z, 0\}. \quad (15.9)$$

候选阈值 η 提高时, 第一项直接增加, 超过阈值的剩余损失却会减少。记花括号中的函数为 $\phi(\eta)$ 。正部函数关于 η 凸且为 1-Lipschitz, 因而可以用有界差商交换单侧极限与期望, 得到

$$\phi'_+(\eta) = 1 - \frac{\mathbb{P}(L > \eta)}{1 - \alpha}, \quad \phi'_-(\eta) = 1 - \frac{\mathbb{P}(L \geq \eta)}{1 - \alpha}.$$

凸函数在 η 处最小当且仅当 $\phi'_-(\eta) \leq 0 \leq \phi'_+(\eta)$, 即

$$\mathbb{P}(L < \eta) \leq \alpha \leq \mathbb{P}(L \leq \eta). \quad (15.10)$$

所以满足该条件的分位阈值达到最小值。连续分布中两侧导数通常相同; 阈值处有原子时, 左右导数不同恰好记录了这部分概率质量。

令 $q = q_\alpha(L)$ 。由 $\mathbb{P}(L > q) \leq 1 - \alpha \leq \mathbb{P}(L \geq q)$, 将 $\eta = q$ 代入阈值式并展开, 得到

$$\text{CVaR}_\alpha(L) = \frac{\mathbb{E}[L \mathbb{I}\{L > q\}] + q((1 - \alpha) - \mathbb{P}(L > q))}{1 - \alpha}. \quad (15.11)$$

第一项计入严格超过 q 的全部损失; 若这部分概率不足 $1 - \alpha$, 第二项就从恰好等于 q 的结果中取出所缺的概率, 使平均恰好覆盖最坏的 $1 - \alpha$ 。若 $\mathbb{P}(L \geq q) = 1 - \alpha$, 便可写成 $\mathbb{E}[L | L \geq q]$; 分布在分位点处连续是保证该质量相等的常见充分条件。未经检查就对整个事件 $\{L \geq q\}$ 平均, 可能纳入过多概率。不过, 两个平均数也可能碰巧相等, 不能仅凭数值相同判断尾部概率是否取对。例如, 常数损失的任意尾部平均都等于该常数。

前面的 L_{safe} 具有 $\text{CVaR}_{0.95} = 1$, L_{tail} 最坏 5% 恰是损失 20, 故其 $\text{CVaR}_{0.95} = 20$ 。期望相同、VaR 较小都没有否定这一严重尾部。

示例 15.5 分位点原子中的部分尾部 设 L 以概率 0.6, 0.3, 0.1 分别取 0, 2, 10, 取 $\alpha = 0.75$ 。由于 $\mathbb{P}(L < 2) = 0.6 < 0.75 \leq \mathbb{P}(L \leq 2) = 0.9$, 分位点为 2。最坏 25% 由损失 10 的全部 10% 质量和损失 2 的部分 15% 质量组成:

$$\text{CVaR}_{0.75}(L) = \frac{0.1 \times 10 + 0.15 \times 2}{0.25} = 5.2.$$

若直接对 $L \geq 2$ 条件化, 得到 $(0.3 \times 2 + 0.1 \times 10)/0.4 = 4$, 平均了 40% 质量, 不是该 CVaR。

图 15.1 给出同一例子的阈值目标。横轴最优点 2 是 VaR, 纵轴最小值 5.2 才是 CVaR; 两个数在计算中承担不同角色。




图 15.1 教学分布 $P(L = 0) = 0.6$, $P(L = 2) = 0.3$, $P(L = 10) = 0.1$ 在 $\alpha = 0.75$ 下的阈值目标 $\phi(\eta) = \eta + 4\mathbb{E}[(L - \eta)_+]$ 。暖黄色折线的最小点为 (2, 5.2); 阈值 2 与尾部平均 5.2 不能混用。

15.2.2.3 基于风险包络的尾部评价

同一个 CVaR 也可以不用移动阈值, 而改成对坏结果增加评价权重。对 $L \in L^1(P)$,

$$\text{CVaR}_\alpha(L) = \sup_{\zeta} \left\{ \mathbb{E}_P[\zeta L] : 0 \leq \zeta \leq \frac{1}{1-\alpha}, \quad \mathbb{E}_P[\zeta] = 1 \right\}. \quad (15.12)$$

ζ 是相对于原分布的密度比; 所有满足这些约束的密度比组成风险包络, 即评价时允许使用的权重集合。上界 $1/(1-\alpha)$ 阻止全部评价质量压到概率小于 $1-\alpha$ 的事件上。

有限分布中, 令结果 i 的原概率为 p_i 、重加权概率为 $q_i = p_i \zeta_i$, 右侧变为线性规划

$$\max_{\mathbf{q}} \sum_i q_i L_i \quad \text{s.t.} \quad 0 \leq q_i \leq \frac{p_i}{1-\alpha}, \quad \sum_i q_i = 1.$$

若较小损失仍有质量而较大损失尚未达到上界, 将一小部分质量转移到较大损失不会降低目标。反复转移便得到从最大损失开始填充的解; 最后一个损失只取部分质量时, 正是式 (15.11) 的边界补足。

一般可积分布也能直接证明等式, 不必只诉诸形式对偶。对任意可行 ζ 和 η ,

$$\mathbb{E}[\zeta L] = \eta + \mathbb{E}[\zeta(L - \eta)] \leq \eta + \frac{\mathbb{E}[(L - \eta)_+]}{1 - \alpha}.$$

对 η 取下确界, 说明任意可行密度的加权期望都不超过 CVaR。反向令 $q = q_\alpha(L)$, $b = (1 - \alpha) - \mathbb{P}(L > q)$ 。若 $\mathbb{P}(L = q) > 0$, 取

$$\zeta^* = \frac{\mathbb{I}\{L > q\}}{1 - \alpha} + \frac{b \mathbb{I}\{L = q\}}{(1 - \alpha)\mathbb{P}(L = q)}.$$

分位条件保证 $0 \leq b \leq \mathbb{P}(L = q)$, 故密度满足上界且期望为 1。若 $\mathbb{P}(L = q) = 0$, 则 $b = 0$, 只保留第一项。计算 $\mathbb{E}[\zeta^* L]$ 得到原子尾部公式, 所以上确界达到 CVaR。

例 15.5 中, 损失 10 的原质量 0.1 至多放大为 0.4, 剩余 0.6 放到损失 2, 重加权重为 (0, 0.6, 0.4)。




图 15.2 损失 0, 2, 10 的名义概率为 (0.6, 0.3, 0.1), $\text{CVaR}_{0.75}$ 的约束为 $q_i \leq 4p_i$ 和 $\sum_i q_i = 1$ 。最优重加权 (0, 0.6, 0.4) 的期望为 5.2。蓝色为名义质量, 红色为对偶最优质量; 真实发生概率并未因评价重加权而改变。

CVaR 的相干性质也可从阈值式逐项核对。 $L \leq L'$ 使每个阈值下的正部期望不增, 取下确界得到单调性。将 $L + m$ 的阈值写成 $\eta = \bar{\eta} + m$, 使得

$\text{CVaR}_\alpha(L + m) = \text{CVaR}_\alpha(L) + m$ 。对 $t > 0$ 令 $\eta = t\bar{\eta}$ 得到正齐次性, $t = 0$ 直接由零损失验证。又由于

$$(L_1 + L_2 - \eta_1 - \eta_2)_+ \leq (L_1 - \eta_1)_+ + (L_2 - \eta_2)_+,$$

先以 $\eta_1 + \eta_2$ 评价合计损失, 再分别对两个阈值取下确界, 得到次可加性, 继而得到凸性。这些性质都不要求损失分布连续。

这个包络是由既定概率和尾部水平 α 规定的评价权重集合。模型不确定性则问真实生成机制可能是哪一个分布。二者都能写成最坏期望, 但一般不是同一集合, 更不能把重加权结果当作重新估计出的真实事故概率。

15.2.3 概率约束与模型不确定性

有些要求不是把风险再加进目标, 而是排除违规概率过大的策略。固定策略产生损失 L , 给定阈值 b 和 $\varepsilon \in (0, 1)$, 机会约束 (chance constraint) 为

$$\mathbb{P}(L > b) \leq \varepsilon. \quad (15.13)$$

它控制超标是否发生, 不区分超标幅度。由于 $\text{VaR}_{1-\varepsilon}(L) \leq \text{CVaR}_{1-\varepsilon}(L)$, 条件 $\text{CVaR}_{1-\varepsilon}(L) \leq b$ 蕴含此机会约束。反向一般不成立, 小概率违规的损失可以很大。

必须把违规事件写清楚。温度任务可以限制终端 $\{x_H > 3\}$ 、某时刻 $\{x_t > 3\}$, 也可以限制整段 $\{\exists t \leq H : x_t \notin [0, 3]\}$ 。若每个时刻违规概率至多为 ε_t , 并集界只给出整段违规概率不超过 $\sum_{t=0}^H \varepsilon_t$; 各时刻都不超过 ε , 不自动使整段也不超过 ε 。期望舒适成本很小同样不能替代这些事件保证。

加入输入限制 $0 \leq u \leq 1$ 和状态限制 $0 \leq x \leq 3$ 时, 先检查可行性。无噪声下, 任意 $x \in [0, 3]$ 取 $u = 0$ 即可留在区间内, 但共同反馈 $u = 1 - 0.3x$ 还需单独核验: 它在区间上取 $[0.1, 1]$, 且下一状态 $x' = 0.5x + 1 \in [1, 2.5]$, 因此可行。为演示有界扰动下的逐路径安全, 这里将第 14 章“策略的实现与轨迹控制”中用于矩计算的高斯噪声改为两点分布; 动力学和反馈不变, 但噪声假设不同。若 w_{t+1} 独立同分布、等概率取 ± 0.1 , 同一反馈有 $x' \in [0.9, 2.6]$, 仍可保持该区间。这一例取状态完全可见, 过程噪声独立于初态及策略私有随机数。若另有观测噪声 v_t 独立同分布且等概率取 ± 0.05 , 并与过程噪声、初态和私有随机数相互独立, 则必须重新检查具体输出反馈; 不能将状态反馈的保证照搬。无界高斯扰动则不能由这种有界输入保证逐路径不越界。

若转移机制由未知 $\theta \in \Theta$ 决定, 固定策略的最坏期望是 $\sup_{\theta \in \Theta} \mathbb{E}_{P_\theta}^\pi[L]$ 。分布鲁棒优化 (distributionally robust optimization, DRO) 使用候选分布集 $\mathcal{P}$, 相应的评价为 $\sup_{Q \in \mathcal{P}} \mathbb{E}_Q^\pi[L]$ 。距离、矩条件或散度可以规定 $\mathcal{P}$, 但集合如何构造和真实分布落入集合的置信保证仍须分别论证; 分布比较工

具本身不会自动给出覆盖保证。优化阶段再对允许策略取下确界，不能在固定策略评价中提前改变行动。

以 L_{safe} 和 L_{tail} 为例， $b = 10, \varepsilon = 0.05$ 时，两者违规概率为 0 和 0.05，都满足机会约束； $\text{CVaR}_{0.95}$ 却为 1 和 20。若第二项损失 20 的概率只知 $p \in [0.02, 0.08]$ ，最坏期望为 $\max_p 20p = 1.6$ ，逐路径最坏损失为 20，而机会约束在整个集合上不成立，因为 $p = 0.08$ 也被允许。这些数分别描述尾部平均、事故概率、最坏模型平均和路径上界。

有限样本空间中，非空闭候选集位于紧致概率单纯形内，线性期望必达到最大值。若集合排除某些结果，保证也只覆盖其允许支持。交换策略的 $\inf$ 与模型的 $\sup$ ，或把内层写成无间隙的对偶，还需凸性、紧致性、连续性或相应约束资格；最坏分布存在并不够。随机波动、参数估计误差和模型歧义由此得到区分。

15.2.4 逐时信息下的动态风险

15.2.4.1 静态尾部评价与偏好反转

从起点评价整条轨迹，与到达某个分支后重新评价剩余损失，是两个不同操作。期望有塔式性质把二者连接起来，静态 CVaR 一般没有同样的关系。考虑一棵两阶段树：起点等概率进入 N 和 B ， N 的损失固定为 2；在 B 可以预先承诺固定方案 F 或随机方案 R ，

$$L_F = 3.5, \quad L_R = \begin{cases} 0, & \text{条件概率 } 1/2, \\ 4, & \text{条件概率 } 1/2. \end{cases}$$

先分别评价这两项承诺策略。承诺 F 时，起点损失以相同概率取 2, 3.5，所以 $\text{CVaR}_{0.5}(L^F) = 3.5$ 。承诺 R 时，起点损失以概率 1/4, 1/2, 1/4 取 0, 2, 4，故

$$\text{CVaR}_{0.5}(L^R) = \frac{(1/4) \times 4 + (1/4) \times 2}{1/2} = 3.$$

静态评价因此偏好 R 。真正到达 B 后，只在该条件分布内重算同一水平的 CVaR，却有

$$\text{CVaR}_{0.5}(L_F | B) = 3.5, \quad \text{CVaR}_{0.5}(L_R | B) = 4,$$

两种方案的排序因此反转。起点评价时， N 的损失占用了静态尾部的一部分；条件化后，未到达的 N 已经排除。反转不是算错，而是整条轨迹的尾部与当前分支的尾部并非同一批结果。

评价口径	承诺 F	承诺 R	比较依据
初始静态 $\text{CVaR}_{0.5}$	3.5	3	整棵树最坏一半的损失
到达 B 后的条件 $\text{CVaR}_{0.5}$	3.5	4	B 内最坏一半的损失
两层嵌套 $\text{CVaR}_{0.5}$	3.5	4	先评价子节点，再评价节点风险

表 15.1 同一两阶段分布的三种评价。根节点等概率到达 N 或 B ， N 固定损失为 2。前两行发生偏好反转；第三行使用下节定义的嵌套目标，其数值不等于静态总损失 CVaR_0 。

15.2.4.2 条件风险与时间一致性

要在每次增加信息后按同一规则评价剩余损失，可以明确规定：下一节点先给出风险值，当前节点再汇总这些值。令 $\mathcal{F}_0 \subseteq \dots \subseteq \mathcal{F}_H$ 为逐时增长的信息；阈值等评价参数只能使用当时已知的信息。

定义 15.6 一步条件风险映射 在同一概率空间上，一步条件风险映射 (conditional risk mapping)

$$\rho_t : L^\infty(\mathcal{F}_{t+1}) \longrightarrow L^\infty(\mathcal{F}_t)$$

把下一时刻可行的有界随机损失转成当前信息下的风险。输入与输出均按几乎处处相等的等价类理解。

常用条件为单调性、当前信息下的平移等变性和归一化：

$$Z \leq Z' \implies \rho_t(Z) \leq \rho_t(Z'), \quad (15.14)$$

$$\rho_t(Z + M) = \rho_t(Z) + M, \quad M \in L^\infty(\mathcal{F}_t), \quad (15.15)$$

$$\rho_t(0) = 0.$$

条件期望满足这些条件。有限树上逐节点评价的映射还具有局部性：若事件 $E \in \mathcal{F}_t$ ，只改变 E 之外的未来损失，不改变 E 内的评价。一般条件模型使用逐节点评价时，也须保证节点上的计算只使用该节点已经获得的信息。

条件 CVaR 为

$$\text{CVaR}_{\alpha,t}(Z) = \operatorname{ess\,inf}_{\eta \in L^\infty(\mathcal{F}_t)} \left\{ \eta + \frac{1}{1-\alpha} \mathbb{E}[(Z - \eta)_+ | \mathcal{F}_t] \right\}. \quad (15.16)$$

η 可随当前历史改变，不能偷看未来结果。记花括号中的 $\mathcal{F}_t$ 可测随机变量为 Φ_η 。这里的本质下确界 (essential infimum) 是在几乎处处大小关系下最大的共同下界：它是 $\mathcal{F}_t$ 可测的随机变量 U ，对每个 η 都有 $U \leq \Phi_\eta$ 几乎处处；任何同样对每个 η 满足 $V \leq \Phi_\eta$ 的 $\mathcal{F}_t$ 可测随机变量 V ，都必须满足 $V \leq U$ 几乎处处。因此结果仍随当前历史变化，并不是对全部历史再取一个常数最小值。这个定义直接在随机变量的几乎处处等价类之间比

较, 避免把不可数多个版本逐点取下确界时的可测性问题藏起来。有限概率树上, 就是在每个当前节点对其条件分布使用静态阈值公式。例如固定前例的承诺 R , 在节点 N 与 B 得到的条件风险分别为 2 与 4。

定义 15.7 嵌套动态风险 设 $C_t \in L^\infty(\mathcal{F}_t)$ 为当前已知的有界损失, 给定一步映射 (ρ_t) , 由终端向前定义

$$\begin{aligned}\mathcal{R}_H(C_H) &= C_H, \\ \mathcal{R}_t(C_t, \dots, C_H) &= C_t + \rho_t(\mathcal{R}_{t+1}(C_{t+1}, \dots, C_H)).\end{aligned}\quad (15.17)$$

称为嵌套动态风险 (nested dynamic risk)。

这里当前成本在风险映射外, 是因为它已经属于 $\mathcal{F}_t$ 。若成本 $\tilde{C}_{t+1}$ 到下一时刻才揭晓, 则应写成

$$\tilde{\mathcal{R}}_t = \rho_t(\tilde{C}_{t+1} + \tilde{\mathcal{R}}_{t+1}).$$

随机行动尚未抽取时, 依赖该行动的阶段成本也属于尚未揭晓的量, 不能无条件提出。

定义 15.8 递归意义下的时间一致性 动态风险族 $(\mathcal{R}_t)$ 具有时间一致性 (time consistency), 是指对每个 $t < H$ 、任意两组从 $t+1$ 开始的有界适应损失和同一当前损失 C_t , 只要 $\mathcal{R}_{t+1}(C_{t+1:H}) \leq \mathcal{R}_{t+1}(C'_{t+1:H})$ 几乎处处成立, 就有 $\mathcal{R}_t(C_t, C_{t+1:H}) \leq \mathcal{R}_t(C_t, C'_{t+1:H})$ 几乎处处成立。

它要求下一时刻每个可能历史上的共同排序在当前仍被保留, 而不是要求某个单一实现总能沿用起点的无条件排序。嵌套结构下, 若每个 ρ_t 单调, 则

$$C_t + \rho_t(\mathcal{R}_{t+1}(C_{t+1:H})) \leq C_t + \rho_t(\mathcal{R}_{t+1}(C'_{t+1:H})),$$

正是所需结论。相同当前损失这个条件不可删除, 否则当前多付的成本本身就可能逆转比较。

回到两节点例, 先固定承诺 F 或 R 。在 B 分别得到风险值 3.5 或 4, 在 N 均为 2; 根节点再对这两个等概率节点值计算 $\text{CVaR}_{0.5}$, 得到 3.5 或 4。所以嵌套评价偏好 F , 静态评价偏好 R 。递归结构保证了上述时间一致性, 但没有把两个不同目标变成同一目标的两种算法。

15.3 策略的轨迹价值计算

15.3.1 有限时域下的价值递推

固定策略后，价值计算不再选择行动，而是把该规则可能产生的未来后果逐层汇总。有限时域从终端开始最直接： $V_H^\pi(s) = c_H(s)$ 。对于给定 Markov 策略，先对下一状态条件化，再按已经指定的行动概率平均，得到

$$V_t^\pi(s) = \sum_a \pi_t(a | s) \left[c_t(s, a) + \sum_{s'} P_t(s' | s, a) V_{t+1}^\pi(s') \right]. \quad (15.18)$$

这就是固定策略的 Bellman 评价式。若下一时刻的价值已算出，一次矩阵求和即可把时刻 t 的价值算出；没有任何 $\min_a$ 。

其依据是塔式法则。把累计和拆成 $c_t(S_t, A_t)$ 与后续和，在 $S_t = s, A_t = a$ 下对后续和条件化，其期望为 $\sum_{s'} P_t(s' | s, a) V_{t+1}^\pi(s')$ ；再对 $\pi_t(a | s)$ 求和，得到上式。归纳到 $t = 0$ 后， $J^\pi = \sum_s \mu_0(s) V_0^\pi(s)$ 。对一般历史策略，同样的证明给出

$$J_t^\pi(h_t) = \sum_a \pi_t(a | h_t) \left[c_t(s, a) + \sum_{s'} P_t(s' | s, a) J_{t+1}^\pi(h_t, a, s') \right].$$

只有当继续规则与所需预测信息都由当前状态概括时，才可把 $J_t^\pi(h_t)$ 缩写为 $V_t^\pi(s)$ 。Markov 环境不意味着任意历史策略本身自动变成 Markov 策略。

在路线例中，固定以概率 p 走捷径的策略有

$$V_0^\pi(s_0) = (1 - p) \times 2 + p(0.8 \times 0 + 0.2 \times 6) = 2 - 0.8p.$$

$p = 1/2$ 给出 1.6。这与按三条轨迹概率 (0.5, 0.4, 0.1) 直接求和一致。递推省去了枚举长轨迹的代价，却没有改变评价对象。

示例 15.9 温度策略的两步成本 取式 (15.1) 无噪声、 $x_0 = 0, H = 2$ ，并按式 (15.7) 计价。固定反馈 $u_t = 0.4 - 0.3(x_t - 2)$ 得到 $(x_0, x_1, x_2) = (0, 1, 1.5)$ 、 $(u_0, u_1) = (1, 0.7)$ 。由终端向前，

$$\begin{aligned} V_2^\pi(1.5) &= 0.25, \\ V_1^\pi(1) &= 1 + 0.49 + 0.25 = 1.74, \\ V_0^\pi(0) &= 4 + 1 + 1.74 = 6.74. \end{aligned}$$

舒适偏差合计 $4 + 1 + 0.25 = 5.25$ ，输入平方合计 $1 + 0.49 = 1.49$ 。另一项固定策略始终取 $u_t = 0.4$ ，产生 $(0, 0.4, 0.72)$ ，其成本为

$$4 + 1.6^2 + 1.28^2 + 0.4^2 + 0.4^2 = 8.5184.$$

其中舒适成本为 8.1984，输入成本为 0.32。所以在这个初态、两步时域和给定权重下，反馈策略用更多输入换来更小的总成本；对应累计收益为 -6.74 和 -8.5184 。这个比较只涉及两项指定策略，并没有证明第一项在所有策略中最优。

图 15.3 将上述评价并列展示：状态更快接近目标，并不意味着每一项成本都较低。反馈增加了输入成本，但在这两步内节省了更多舒适成本。




图 15.3 共同温度模型下两项固定策略的比较。左图连接离散时刻的状态，黄色虚线为目标温差 2；连线仅用于辨认轨迹，不表示额外的连续时间模型。右图按 $c(x, u) = (x - 2)^2 + u^2$ 和终端成本 $(x - 2)^2$ 累计，柱顶数值保留两位小数。反馈的精确总成本为 6.74，固定输入的总成本为 8.5184。先分别求值再比较，并未在每一步重新选择最优行动。

恢复随机扰动后，同一反馈诱导轨迹分布而非上述单一路径。若成本可积，可以沿条件分布求期望；不能只把噪声取均值零后代回非线性的平方成本。例如 $\mathbb{E}[(x - r)^2] = (\mathbb{E}[x] - r)^2 + \text{Var}(x)$ ，漏掉方差项就低估了舒适成本。

15.3.2 无限折扣时域下的价值计算

有限时域有一个可以启动反向计算的终端，无限时域则没有最后一步。折扣和有界成本使远期影响可控，由此可把评价转化为固定点计算。以下取有限状态行动、时不变转移、 $|c(s, a)| \leq C$ 、 $0 \leq \gamma < 1$ 和给定的平稳 Markov 策略 π 。定义

$$c^\pi(s) = \sum_a \pi(a | s) c(s, a), \quad P^\pi(s, s') = \sum_a \pi(a | s) P(s' | s, a),$$

以及固定策略评价算子

$$(T^\pi V)(s) = c^\pi(s) + \gamma \sum_{s'} P^\pi(s, s') V(s'). \quad (15.19)$$

由 $P^\pi(s, s')$ 组成的矩阵每行非负且和为 1，所以对任意两个价值函数，

$$|(T^\pi V)(s) - (T^\pi W)(s)| \leq \gamma \sum_{s'} P^\pi(s, s') |V(s') - W(s')| \leq \gamma \|V - W\|_\infty.$$

取状态最大值便得到 γ -压缩。有限维最大范数空间完备，压缩映射定理给出唯一固定点。另一方面，折扣成本的绝对和不超过 $C/(1-\gamma)$ ，可合法拆出第一项并条件化，得到 $V^\pi = T^\pi V^\pi$ 。因此这个唯一固定点正是指定策略的期望累计成本，不是最优成本。

从任意 $V^{(0)}$ 出发令 $V^{(k+1)} = T^\pi V^{(k)}$ ，有

$$\|V^{(k)} - V^\pi\|_\infty \leq \gamma^k \|V^{(0)} - V^\pi\|_\infty. \quad (15.20)$$

若取 $V^{(0)} = 0$ ，右侧可用 $\gamma^k C/(1-\gamma)$ 替代。不知 V^π 时，也可用可计算残差

$$\|V - V^\pi\|_\infty \leq \frac{\|T^\pi V - V\|_\infty}{1-\gamma},$$

因为三角不等式和压缩性给出 $\|V - V^\pi\|_\infty \leq \|V - T^\pi V\|_\infty + \gamma \|V - V^\pi\|_\infty$ 。这给出一个可计算的误差上界，用来判断何时可以停止评价迭代。

将 $c^\pi(s), V^\pi(s)$ 排列为列向量 $\mathbf{c}^\pi, \mathbf{V}^\pi$ ，以 $P^\pi(s, s')$ 为元素组成矩阵 $\mathbf{P}^\pi$ ，则

$$\mathbf{V}^\pi = (\mathbf{I} - \gamma \mathbf{P}^\pi)^{-1} \mathbf{c}^\pi = \sum_{j=0}^{\infty} \gamma^j (\mathbf{P}^\pi)^j \mathbf{c}^\pi.$$

无穷级数在最大范数下收敛，故逆矩阵存在。单状态例中，若策略每步以概率 1/4 选择成本 4 的行动，其余选择成本 0 的行动，则 $c^\pi = 1$ ； $\gamma = 0.9$ 时 $V^\pi = 10$ ，从零开始迭代得到 $V^{(k)} = 10(1 - 0.9^k)$ 。这里平均的是固定行动分布；若把每步成本改成两行动中较小的 0，算出的已是另一个优化问题。

非平稳或一般历史策略仍有定义良好的有界折扣价值，但其继续规则可能随时间或历史变化，不能直接使用这个单一平稳算子。可以保留时间、扩充状态，或对有限截断时域评价后控制余项。连续状态无界二次成本也需要另行选择函数空间与矩条件。

15.3.3 风险评价下的价值计算

15.3.3.1 嵌套风险下的递推计算

先固定确定性 Markov 策略 $a = \pi_t(s)$ 。若当前状态确实包含风险评价所需的信息，一步风险映射可写为 $\rho_{t,s,a}$ ，它作用于按 $P_t(\cdot | s, a)$ 分布的下一状态。从终端开始计算

$$V_H^{\pi,\rho}(s) = c_H(s), \quad V_t^{\pi,\rho}(s) = c_t(s, \pi_t(s)) + \rho_{t,s,\pi_t(s)}(V_{t+1}^{\pi,\rho}(S_{t+1})).$$

其含义与定义 15.7 完全一致：先接受后续节点的评价，再按当前节点风险汇总。策略仍固定，不从其他行动中挑更小的一个。

随机策略需要多说明一层。采取行动之前， A_t 尚未揭晓；可在联合条件分布 $\pi_t(a | s)P_t(s' | s, a)$ 上，对行动和下一状态一起评价：

$$V_t^{\pi,\rho}(s) = \rho_{t,s}^{\pi}(c_t(s, A_t) + V_{t+1}^{\pi,\rho}(S_{t+1})). \quad (15.21)$$

这里 $\rho_{t,s}^{\pi}$ 的输入是 (A_t, S_{t+1}) 上的随机损失，连当前阶段成本也必须放在映射内。另一种明确可定义的目标，是先对每个已选行动的环境后果计算风险，再对行动随机化使用期望：

$$\bar{V}_t^{\pi,\rho}(s) = \sum_a \pi_t(a | s) \left[c_t(s, a) + \rho_{t,s,a}(\bar{V}_{t+1}^{\pi,\rho}(S_{t+1})) \right].$$

这个公式不是从前式用线性性推出来的，而是改变了行动随机性的评价口径。路线策略 $p = 1/2$ 时，联合损失概率为 0.4 取 0、0.5 取 2、0.1 取 6，联合 $\text{CVaR}_{0.9}$ 为 6；先分别算行动的 CVaR 再平均，得到 $\frac{1}{2} \times 2 + \frac{1}{2} \times 6 = 4$ 。期望下两种次序相同，非线性风险下通常不同。

误差控制依靠单调性和平移等变性，而不依靠线性性。设有限状态上的 $\|V - W\|_{\infty} \leq \delta$ ，则 $W(S') - \delta \leq V(S') \leq W(S') + \delta$ ，因此

$$\rho_{s,a}(W(S')) - \delta \leq \rho_{s,a}(V(S')) \leq \rho_{s,a}(W(S')) + \delta.$$

每个映射在最大范数下非扩张。有限时域中一次评价误差不会被单步放大；若第 t 步另引入至多 ϵ_t 的数值误差，则反向传播后的初始误差至多为终端误差加 $\sum_{t=0}^{H-1} \epsilon_t$ 。

无限时域可明确选用“折扣后续风险值”的递归目标。固定确定策略的算子为

$$(T_{\rho}^{\pi}V)(s) = c(s, \pi(s)) + \gamma \rho_{s,\pi(s)}(V(S')).$$

归一化、单调和平移等变保证它把有界向量映到有界向量，且为 γ -压缩，因而有唯一固定点，迭代误差与残差界分别为 $\gamma^k \|V^{(0)} - V^{\pi,\rho}\|_{\infty}$ 和 $\|T_{\rho}^{\pi}V - V\|_{\infty}/(1-\gamma)$ 。后续风险乘 γ 是本目标的明确约定；对 CVaR 等正齐次风险，它也等于 $\rho_{s,\pi(s)}(\gamma V(S'))$ 。一般凸风险不一定允许把 γ 移入或移出。若使用

随机行动的联合目标 $\rho_s^\pi(c(s, A) + \gamma V(S'))$ ，相同非扩张论证仍给出 γ -压缩，但它是该联合目标自己的固定点，不能与前一个目标混称。

上述证明中的 V, W 是有限状态上的实际向量。推广到一般 L^∞ 等价类时，还须保证转移核不会读取所选代表在零测集上的任意值；有限状态的最大范数论证不能未经核对直接替换成本质上确界版本。

风险包络进一步解释这项计算何时等价于局部最坏模型。先在有 m 个结果的有限空间上取相干风险 $\rho : \mathbb{R}^m \rightarrow \mathbb{R}$ ，定义

$$\Omega = \{q \in \mathbb{R}^m : \langle q, z \rangle \leq \rho(z) \text{ 对所有 } z \in \mathbb{R}^m\}.$$

正齐次与次可加使 ρ 为处处取有限值的次线性函数。其凸共轭在 Ω 上为零，在其外为无穷：若某个 z 违反支撑不等式，将 z 放大即使共轭发散。有限凸函数连续，Fenchel–Moreau 表示因而给出 $\rho(z) = \sup_{q \in \Omega} \langle q, z \rangle$ 。将 $r\mathbf{1}$ 代入支撑不等式，并令 r 取任意正负值，平移等变性迫使 $\langle q, \mathbf{1} \rangle = 1$ ；若 $q_i < 0$ ，取 $z = -re_i$ 且 $r > 0$ ，单调性给出 $\rho(z) \leq \rho(0) = 0$ ，却有 $\langle q, z \rangle > 0$ ，矛盾。因此 $q_i \geq 0$ 。支撑表示保证集合非空，且它是概率单纯形中的闭凸集，所以紧致，最大值达到。

一般归一化、单调、平移等变的凸风险未必正齐次，其对偶为

$$\rho(z) = \sup_{q \in \Delta_m} \{\langle q, z \rangle - \beta(q)\}, \quad \Delta_m = \{q \geq 0 : \langle q, \mathbf{1} \rangle = 1\}.$$

β 是可取无穷的凸罚函数，不能无条件删去。相干一步映射则有

$$\rho_{s,a}(V(S')) = \sup_{q \in \Omega(s,a)} \sum_{s'} q(s' | s, a) V(s'). \quad (15.22)$$

条件 CVaR 对应相对于名义转移的有界密度比。固定策略后逐步代入这些包络，究竟是否等于原先声明的整条轨迹最坏期望，还取决于各节点的模式选择能否自由拼接。

定义 15.10 条件分布集合的矩形性 在有限概率树上，为每个历史行动节点给定非空下一步条件分布集合。若允许的路径分布恰好包括从各节点集合任意选取条件核，再按路径相乘得到的全部分布，则称该不确定集合具有矩形性 (rectangularity)。

Markov 表达中可使用 $\Omega(s, a)$ ，但模型的局部选择仍可依赖已发生历史，且不受“其他节点必须使用同一个未知参数”等跨节点约束。固定策略不变时，逆向归纳说明矩形集合的最坏期望可逐节点求得：最末节点选其最坏条件分布；前一节点对这些已取得的继续值取最坏期望；矩形性保证各节点的选择能拼成同一允许路径模型。反过来，任一允许模型的局部期望不超过该局部上确界，逐步回代得到上界。有限树和紧致局部包络保证所

有最大值同时可达；没有达到性时可改用近似最坏选择。这一证明没有改变策略，也没有加入行动最小化。

若一个未知参数全程固定，矩形性通常不成立。设 $Y_1, Y_2 \in \{0, 1\}$ 在给 $p \in \{0.2, 0.8\}$ 后独立，两次共用该 p 。原模型下

$$\mathbb{P}_p(Y_1 = 1, Y_2 = 0) = p(1 - p) = 0.16.$$

若每个节点可独立取最坏 p ，第一步选 0.8，看到 $Y_1 = 1$ 后第二步改选 0.2，则该事件概率为 $0.8 \times 0.8 = 0.64$ 。这个概率不属于任何原来的固定参数模型。局部递推实际扩大了候选机制，所以它得到的风险值并不是原先固定参数问题的精确答案。可以保留共享参数约束，或在有先验的模型中更新其信念并扩充状态；只把候选分布集写进 Bellman 式，仍无法表达多个时刻必须共用同一参数的约束。

15.3.3.2 静态尾部风险下的增广计算

如果仍然要评价起点处的静态总损失 CVaR，就不应更换成嵌套目标。以有限时域折扣损失 $L = \sum_{t=0}^{H-1} \gamma^t c_t(S_t, A_t) + \gamma^H c_H(S_H)$ 为例，这里也允许 $\gamma = 1$ 。固定策略 π 和阈值 η 后，需要计算的是 $\mathbb{E}^\pi[(L - \eta)_+]$ 。同一物理状态可能由不同历史到达，已经累计的损失不同，越过阈值的剩余空间也不同，因此原状态通常不够。

把已累计成本记为 $B_0 = 0, B_{t+1} = B_t + \gamma^t c_t(S_t, A_t)$ 。若固定策略为 $\pi_t(a | s, b)$ ，定义在增广状态上的终端与递推

$$\begin{aligned} W_H^{\pi, \eta}(s, b) &= (b + \gamma^H c_H(s) - \eta)_+, \\ W_t^{\pi, \eta}(s, b) &= \sum_a \pi_t(a | s, b) \sum_{s'} P_t(s' | s, a) W_{t+1}^{\pi, \eta}(s', b + \gamma^t c_t(s, a)). \end{aligned} \quad (15.23)$$

这仍是普通条件期望评价，正部非线性全部留在终端。原 Markov 策略是这里不依赖 b 的特例；若给定策略还读取未被 (s, b) 保留的历史，就继续保留那部分历史，不能因成本已增广而擅自改写原策略。

计算完每个阈值的期望以后，该固定策略的风险为

$$\text{CVaR}_\alpha(L^\pi) = \inf_{\eta \in \mathbb{R}} \left\{ \eta + \frac{1}{1 - \alpha} \sum_s \mu_0(s) W_0^{\pi, \eta}(s, 0) \right\}.$$

这里优化 η 只是计算 CVaR 定义中的辅助参数，并没有优化策略。例如在累计成本 $b = 0$ 或 $b = 5$ 时都到达同一零终端成本状态，阈值 $\eta = 3$ 对应正部损失 0 和 2，足见只记录物理状态无法作相同的终端结算。增广状态可能连续，计算规模会增加；无界成本需要正部期望有限。下一节才允许策略随增广状态改变，并说明这时阈值与策略如何联合优化。

15.4 策略的轨迹价值优化

前一节对指定行动规则求值，现在才把规则本身作为变量。最优性总是相对于允许信息、可行行动和既定准则而言：降低期望成本不保证每条实现轨迹都更好，也不自动保证安全。单步选择先展示“按后果比较行动”，多步问题再把后果换成当前成本加最优继续价值。

15.4.1 单步价值下的行动选择

只有一次行动时，轨迹损失退化为 $\ell(a, Y)$ 。设观测为 X ，未知结果 $Y \in \mathcal{Y}$ ，可选行动 $a \in \mathcal{A}$ ，损失 $\ell : \mathcal{A} \times \mathcal{Y} \rightarrow \mathbb{R}$ 给出每种行动在每种结果下的代价。结果未揭晓前不能逐列挑选最低损失，只能依据当前可用的条件分布选择一整项行动。

定义 15.11 条件风险与 Bayes 决策 给定条件分布核 $P(dy | x)$ ，假设损失可测且下列期望有限。行动 a 在观测 x 下的条件风险(conditional risk) 为

$$r(a | x) = \mathbb{E}[\ell(a, Y) | X = x] = \int_{\mathcal{Y}} \ell(a, y) P(dy | x). \quad (15.24)$$

若最小值达到，任取

$$a^*(x) \in \arg \min_{a \in \mathcal{A}} r(a | x) \quad (15.25)$$

称为 Bayes 行动 (Bayes action)。若该选择关于 x 可测，映射 $\delta^*(x) = a^*(x)$ 称为 Bayes 决策规则 (Bayes decision rule)。

有限类别时，积分就是 $\sum_y \ell(a, y) p(y | x)$ 。这里“Bayes”指按照给定条件分布最小化期望损失；该分布可以由先验和似然更新，也可以由其他概率模型给出。Bayes 公式更新信念，Bayes 规则把信念转成行动，二者不是同一步。

可测规则 δ 的总体风险为

$$R(\delta) = \mathbb{E}[\ell(\delta(X), Y)]. \quad (15.26)$$

塔式法则和逐点最小性给出完整的总体比较：

$$R(\delta^*) = \mathbb{E}[\mathbb{E}[\ell(\delta^*(X), Y) | X]] = \mathbb{E}[\min_a r(a | X)] \leq \mathbb{E}[r(\delta(X) | X)] = R(\delta).$$

期望存在和可测选择不可省略。有限行动可以按固定次序处理并列；连续行动还要检查成本的可测性、下半连续性及其最小值达到条件，否则下确界未必对应一项可实施规则。

示例 15.12 有限损失表的逐项计算 设 $Y \in \{y_0, y_1\}$, 损失表为

	y_0	y_1
a_0	0	6
a_1	2	1

若 $\mathbb{P}(Y = y_1 | X = x) = 1/4$, 则

$$r(a_0 | x) = \frac{3}{4} \times 0 + \frac{1}{4} \times 6 = \frac{3}{2}, \quad r(a_1 | x) = \frac{3}{4} \times 2 + \frac{1}{4} \times 1 = \frac{7}{4}.$$

Bayes 行动是 a_0 。比较的是各整行的概率加权损失, 不能先观察尚未知的结果, 再在每列选较小数字。一般有限结果 $\{y_1, \dots, y_m\}$ 使用 $r(a | x) = \sum_{j=1}^m \ell(a, y_j) \mathbb{P}(Y = y_j | X = x)$ 。

非对称错误代价会改变同一预测概率对应的行动。二分类中令 $p(x) = \mathbb{P}(Y = 1 | X = x)$, 正确预测损失为零, 假阳性和假阴性损失分别为 $c_{FP} > 0, c_{FN} > 0$ 。两行动风险为

$$r(1 | x) = c_{FP}(1 - p(x)), \quad (15.27)$$

$$r(0 | x) = c_{FN}p(x). \quad (15.28)$$

预测阳性当且仅当第一项不大于第二项, 即

$$p(x) \geq \frac{c_{FP}}{c_{FP} + c_{FN}}. \quad (15.29)$$

等号处风险并列, 可按约定处理。错误代价相同时阈值为 $1/2$; 漏诊代价增加使阈值下降。概率模型并未变化, 变化的是对后果的计价。概率校准良好不能替代正确损失设定。

示例 15.13 同一概率对应不同合理行动 设 $p(x) = 0.3$ 。对称零一损失的阈值为 0.5 , 应预测阴性。若漏诊损失为 9 、误报损失为 1 , 阈值变为 $1/(1 + 9) = 0.1$, 应预测阳性。这些教学数值只说明概率之外还需要价值判断, 不为具体应用决定真实代价。

图 15.4 把行动比较画成两条风险曲线的下包络。“更谨慎”必须说明针对哪一种错误, 才能判断阈值往哪里移动。

允许拒答时, 行动集合又发生改变。令类别为 $\{1, \dots, K\}$, 分类采用零一损失, 增加拒答行动 $\perp$, 其成本为 $c_R \in (0, 1)$ 。最可能类别的条件错误风




图 15.4 二分类的条件风险。蓝色实线是预测阳性的 $c_{FP}(1-p)$ ，红色虚线是预测阴性的 $c_{FN}p$ 。左图两种错误成本均为 1，阈值 0.5；右图漏诊成本增至 9，阈值降为 0.1。横轴相同，纵轴分别显示各自损失范围。

险为 $1 - p_{\max}(x)$ ，其中 $p_{\max}(x) = \max_k \mathbb{P}(Y = k | X = x)$ 。与拒答成本比较得

$$\delta^*(x) = \begin{cases} \arg \max_k \mathbb{P}(Y = k | X = x), & p_{\max}(x) \geq 1 - c_R, \\ \perp, & p_{\max}(x) < 1 - c_R. \end{cases} \quad (15.30)$$

类别并列仍按固定次序选择。拒答是有自身代价的行动，不是结果分布中的新类别。定义覆盖率（coverage）和正覆盖率下的接受风险

$$\text{Coverage}(\delta) = \mathbb{P}\{\delta(X) \neq \perp\}, \quad R_{\text{acc}}(\delta) = \mathbb{E}[\ell(\delta(X), Y) | \delta(X) \neq \perp].$$

这里的覆盖率是接受行动的输入比例；第 10.5.3.2 节预测集合的覆盖率 $\mathbb{P}\{Y \in C(X)\}$ 则衡量集合包含真实响应的概率。两者使用同一名称，但判断的事件不同。多拒绝样本可以降低接受风险，所以必须同时报告覆盖率。固定拒答成本最小化的是包含拒答损失的总体风险，不等于任意指定覆盖率下的接受风险最小化。

人工复核预算会耦合不同观测点。若要求覆盖率至少为 κ ，问题为

$$\min_{\delta} R(\delta) \quad \text{s.t.} \quad \mathbb{P}\{\delta(X) \neq \perp\} \geq \kappa.$$

在适当条件下，拉格朗日乘子可以把覆盖预算换成拒答的影子价格，仍产生阈值规则，但阈值由整体分布和预算决定。选择性预测（selective prediction）选择在哪些输入上行动，不等同于增大某类错误的代价。

示例 15.14 覆盖预算耦合两个观测点 设 X 等概率取 x_1, x_2 , 两处最优分类错误风险为 0.2, 0.4, 拒答损失均为 0.1。逐点无约束规则会全部拒答, 覆盖率为零。要求覆盖率至少 1/2 且使用确定规则时, 至少接受一个点。接受 x_1 、拒答 x_2 的总体风险为 $\frac{1}{2} \times 0.2 + \frac{1}{2} \times 0.1 = 0.15$; 反向安排为 $\frac{1}{2} \times 0.1 + \frac{1}{2} \times 0.4 = 0.25$; 全部接受为 0.3。因此应把有限接受量安排在 x_1 。预算使两个观测点不能再独立执行原拒答规则。

若观测和行动有限, 并允许按每个观测的行动概率优化, 风险与覆盖约束都是线性的, 得到线性规划, 强对偶提供影子价格。只允许确定规则时, 选择变量带零一约束, 一般成为整数规划, 不能套用普通 LP 强对偶。连续分布或非凸策略类还要检查可行性、闭性与约束资格, 不能仅写出乘子就宣称不存在对偶间隙。

还可以用条件风险判断: 在已有信息不变时, 随机选择行动能否降低成本。给定 x , 按概率核 $q(da | x)$ 选行动的风险为

$$\int_{\mathcal{A}} r(a | x) q(da | x) \geq \inf_a r(a | x).$$

有限或可数行动时就是加权和。没有额外耦合约束, 随机化不能优于最佳纯行动; 最小值达到时, 只有将概率放在最优行动上才保持最优。若存在总体预算、公平或资源约束, 随机化可以实现确定规则达不到的平均比例。它在这些情形下有用, 是因为改变了哪些比例可实现, 而非因为平均损失本身偏好随机行动。

15.4.2 离散演化下的策略优化

15.4.2.1 有限时域下的最优策略递推

多步任务中, 行动的“损失表”要把后续机会也计入。先计算最后一步可以达到的最小成本, 再用它评价前一步行动, 就得到

$$V_H^*(s) = c_H(s), \quad (15.31)$$

$$V_t^*(s) = \min_{a \in \mathcal{A}(s)} \left\{ c_t(s, a) + \sum_{s'} P_t(s' | s, a) V_{t+1}^*(s') \right\}. \quad (15.32)$$

与固定评价式(15.18)相比, 这里才出现行动最小化; 被最小化的是当前成本与继续价值之和, 不只是当前成本。

定理 15.15 有限时域最优性原理 在定义 15.1 的有限 MDP 中, 对每个末状态为 s 的历史 h_t , 上述递推满足 $V_t^*(s) = \inf_{\pi} J_t^{\pi}(h_t)$, 其中下确界遍历全部允许的历史依赖随机继续策略。各时刻各状态选择一个达到最小值的行动, 构成达到该值的确定性 Markov 策略。

证明. 用逆向归纳。时刻 H 没有行动, 终端成本就是最小继续成本。假设每段末状态为 s' 的历史 h_{t+1} 的最小继续成本均为 $V_{t+1}^*(s')$ 。固定末状态为 s 的 h_t , 任意策略先按 $\pi_t(a | h_t)$ 选行动。给定 a, s' 后, 归纳假设说明其后续条件期望至少为 $V_{t+1}^*(s')$ 。Markov 转移保证下一状态分布是 $P_t(\cdot | s, a)$, 所以

$$J_t^{\pi}(h_t) \geq \sum_a \pi_t(a | h_t) \left[c_t(s, a) + \sum_{s'} P_t(s' | s, a) V_{t+1}^*(s') \right] \geq V_t^*(s).$$

最后一步是有限个行动后果的凸组合不小于最小项。反向在当前选择一个最小行动, 并在每个下一状态采用归纳构造的最优 Markov 策略, 所有不等式均取等号。有限行动保证每次最小值达到, 逆推到起点即得结论。■

证明比较了所有历史随机策略, 不只比较 Markov 策略。Markov 策略足够, 是因为当前状态概括了转移和期望累计目标所需信息; 遗漏状态、整段轨迹的非加性指标或跨历史预算都可能破坏这个前提。

示例 15.16 一次行动的路线选择 回到前面固定的路线分布。终端价值就是终端损失, 当前成本均为零, 因而

$$Q_0(s_0, \text{稳妥}) = 2, \quad Q_0(s_0, \text{捷径}) = 0.8 \times 0 + 0.2 \times 6 = 1.2.$$

这里 Q_0 表示先指定当前行动、以后最优时的成本。期望准则应选择捷径, 而固定随机策略的成本 $2 - 0.8p$ 也在 $p = 1$ 达到最小。没有声称捷径每次都更好; 它有概率 0.2 产生比稳妥更高的损失。

表 15.2 保留同一轨迹模型, 但改换评价口径。风险偏好属于任务设定, 不能在算完期望最优后将它解释成任意意义下的“最稳妥”。

损失评价	稳妥	捷径
$E[L]$	2	1.2
$P(L > 3)$	0	0.2
$\text{VaR}_{0.9}(L)$	2	6
$\text{CVaR}_{0.9}(L)$	2	6

表 15.2 固定路线分布下的不同评价。捷径最坏 10% 完全位于损失 6 的原子中, 所以此处 VaR 与 CVaR 相同; 这不是一般恒等式。增加违规概率预算后需重新选择策略。

15.4.2.2 无限折扣时域下的最优策略计算

保留有限状态行动、时不变转移、有界成本及 $0 \leq \gamma < 1$ 。与给定策略的 T^π 不同, Bellman 最优算子为

$$(TV)(s) = \min_{a \in \mathcal{A}(s)} \left\{ c(s, a) + \gamma \sum_{s'} P(s' | s, a) V(s') \right\}. \quad (15.33)$$

对有限实数族 $(u_a), (v_a)$, $|\min_a u_a - \min_a v_a| \leq \max_a |u_a - v_a|$ 。结合转移概率的非负性与归一化, 得到

$$\begin{aligned} |(TV)(s) - (TW)(s)| &\leq \gamma \max_a \left| \sum_{s'} P(s' | s, a) (V(s') - W(s')) \right| \\ &\leq \gamma \|V - W\|_\infty, \end{aligned} \quad (15.34)$$

$$\|TV - TW\|_\infty \leq \gamma \|V - W\|_\infty. \quad (15.35)$$

有限维最大范数空间完备, 定理 3.17 给出唯一固定点 V^* 。价值迭代 $V^{(k+1)} = TV^{(k)}$ 从任意初值出发满足

$$\|V^{(k)} - V^*\|_\infty \leq \gamma^k \|V^{(0)} - V^*\|_\infty. \quad (15.36)$$

固定点评价与最优性仍是两件事, 必须证明该点由策略达到, 并且不大于所有其他策略价值。

在每个状态选一个使 $TV^*(s)$ 取到最小值的行动, 得到平稳确定策略 π^* 。此时 $T^{\pi^*} V^* = TV^* = V^*$ 。固定策略评价算子的唯一固定点是 V^{π^*} , 由唯一性得 $V^{\pi^*} = V^*$, 所以候选值可实现。

再对任意历史依赖随机策略 π 比较。固定点满足每个状态行动的不等式

$$V^*(s) \leq c(s, a) + \gamma \sum_{s'} P(s' | s, a) V^*(s').$$

沿策略实际选择的行动条件化, 再把下一步的不等式代入, 重复 n 步得到

$$V^*(s) \leq \mathbb{E}_s^\pi \left[\sum_{t=0}^{n-1} \gamma^t c(S_t, A_t) + \gamma^n V^*(S_n) \right]. \quad (15.37)$$

该操作不要求 π 平稳, 因为每一历史选择的行动都满足同一 Bellman 不等式。余项绝对值至多 $\gamma^n \|V^*\|_\infty$, 趋于零; 有界成本保证折扣级数可积。令 $n \rightarrow \infty$ 得到 $V^*(s) \leq V^\pi(s)$ 。与可达到性合起来, π^* 对全部允许历史随机策略最优。

若 $\gamma = 1$ ，严格压缩和尾项消失不再自动成立。长期平均成本

$$\limsup_{T \rightarrow \infty} \frac{1}{T} \mathbb{E}^\pi \left[\sum_{t=0}^{T-1} c(S_t, A_t) \right]$$

采用了不同的目标：它衡量长期每步的成本，不是令折扣系数为 1 后直接累加全部成本。要用同一个标量描述各初态的长期最优平均，需控制策略诱导链的常返结构。有限模型的一种常见假设是：每项平稳确定性策略诱导的链都只有一个封闭常返类，允许其余状态在进入该类之前被访问。这称为单链（unichain）假设；它不要求只有一个状态，也不要求所有策略产生同一个转移矩阵。在有限状态行动的单链模型中，平均成本最优性方程可写为

$$g + h(s) = \min_a \left\{ c(s, a) + \sum_{s'} P(s' | s, a) h(s') \right\}.$$

其中 g 是最优的长期每步平均成本，相对价值（relative value） $h(s)$ 记录从不同状态出发时，相对于这个平均基线的成本偏移。对达到右侧最小值的平稳策略，逐步求和给出

$$\mathbb{E}_s \sum_{t=0}^{n-1} c(S_t, A_t) = ng + h(s) - \mathbb{E}_s h(S_n).$$

这说明 ng 负责随时间增长的主项， h 负责起点与终点的修正；有限状态下有界的修正除以 n 后消失。方程的存在性属于平均成本理论，不能由前面的折扣压缩证明直接推出³。

例如没有行动选择，两状态 s_0, s_1 确定性交替，阶段成本分别为 0, 2。长期平均为 $g = 1$ ；取 $h(s_0) = 0, h(s_1) = 1$ ，两状态的方程分别为 $1 = 0 + 1$ 与 $2 = 2 + 0$ 。无折扣累计成本随时间发散， h 却只记录状态之间的有限偏移。给 h 加任意常数仍满足同一方程，可以约定参考状态 $h(s_{\text{ref}}) = 0$ 消除这一自由度；这不等于已有折扣固定点的唯一性证明仍然适用。

连续状态或行动中，还需可测转移、适当的成本下半连续性、非空可行动作及紧致性或强制性条件，再用可测选择将点态最小行动拼成策略。部分观测时只能使用允许信息；信念状态只有在充分概括历史时才能承担这一角色。形式上写出 $\inf$ 不等于它可达到。

15.4.2.3 基于价值界与占用流量的最优性验证

Bellman 不等式给出一个有用的验证办法：提出一组状态价值下界，检查它对所有行动都成立。下面把这一检查写成线性规划，再从其对偶问题中

³ M. L. Puterman, *Markov Decision Processes: Discrete Stochastic Dynamic Programming*, Wiley, 1994

恢复策略实际访问各状态、行动的折扣频率。这样既能验证价值下界，也能检查有没有策略达到它。给定初始分布 μ_0 ，价值端 LP 为

$$\begin{aligned} \max_V \quad & (1 - \gamma) \sum_s \mu_0(s) V(s) \\ \text{s.t.} \quad & V(s) \leq c(s, a) + \gamma \sum_{s'} P(s' | s, a) V(s'), \quad s \in \mathcal{S}, a \in \mathcal{A}(s). \end{aligned} \quad (15.38)$$

任意可行 V 满足 $V \leq TV$ ，算子单调使 $V \leq TV \leq T^2V \leq \dots$ 。令迭代收敛得到 $V \leq V^*$ ； V^* 自身可行，因而达到最优值。若 μ_0 不在所有状态上为正，LP 最优解未必唯一，但逐状态最大的可行向量仍是 V^* 。

为每条不等式引入 $d(s, a) \geq 0$ 。最大化原问题的拉格朗日函数为

$$\begin{aligned} \mathcal{L}(V, d) = & (1 - \gamma) \sum_s \mu_0(s) V(s) \\ & - \sum_{s, a} d(s, a) \left[V(s) - c(s, a) - \gamma \sum_{s'} P(s' | s, a) V(s') \right]. \end{aligned}$$

由于 V 自由取实值， $\sup_V \mathcal{L}(V, d)$ 有限当且仅当每个 $V(s)$ 的系数为零，即

$$\sum_a d(s, a) = (1 - \gamma) \mu_0(s) + \gamma \sum_{\bar{s}, \bar{a}} P(s | \bar{s}, \bar{a}) d(\bar{s}, \bar{a}). \quad (15.39)$$

余下常数项为 $\sum_{s, a} d(s, a) c(s, a)$ ，得到对偶

$$\begin{aligned} \min_d \quad & \sum_{s, a} d(s, a) c(s, a) \\ \text{s.t.} \quad & \text{式 (15.39),} \quad d(s, a) \geq 0. \end{aligned} \quad (15.40)$$

原 LP 可行且有有限最优值，对偶也由下述任一策略产生可行点，故有限 LP 强对偶定理 4.28 给出两端最优值相等。

定义 15.17 归一化折扣占用度量 给定初始分布 μ_0 、 $0 \leq \gamma < 1$ 和允许策略 π ，归一化折扣 占用度量 (occupancy measure) 为

$$d_\pi(s, a) = (1 - \gamma) \mathbb{E}_{S_0 \sim \mu_0}^\pi \left[\sum_{t=0}^{\infty} \gamma^t \mathbb{I}\{S_t = s, A_t = a\} \right]. \quad (15.41)$$

它把同一状态行动在不同时刻的访问概率折扣相加，总质量为 1，通常不是 Markov 链的平稳分布。一般历史策略也有这样的占用。分离 $t = 0$ 并将剩余时间索引前移，得到

$$\begin{aligned}\sum_a d_\pi(s, a) &= (1 - \gamma) \sum_{t=0}^{\infty} \gamma^t \mathbb{P}^\pi(S_t = s) \\ &= (1 - \gamma) \mu_0(s) + \gamma(1 - \gamma) \sum_{t=0}^{\infty} \gamma^t \sum_{\bar{s}, \bar{a}} \mathbb{P}^\pi(S_t = \bar{s}, A_t = \bar{a}) P(s | \bar{s}, \bar{a}) \\ &= (1 - \gamma) \mu_0(s) + \gamma \sum_{\bar{s}, \bar{a}} P(s | \bar{s}, \bar{a}) d_\pi(\bar{s}, \bar{a}).\end{aligned}$$

所以流量方程的两项正是起点注入和后续转移注入。对状态求和得 $\sum_{s,a} d_\pi(s, a) = (1 - \gamma) + \gamma \sum_{s,a} d_\pi(s, a)$ ，从而总质量为 1。成本对应关系为

$$\sum_{s,a} d_\pi(s, a) c(s, a) = (1 - \gamma) \mathbb{E}_{S_0 \sim \mu_0}^\pi \left[\sum_{t=0}^{\infty} \gamma^t c(S_t, A_t) \right]. \quad (15.42)$$

反过来，任一可行非负流量 d 也能实现。令 $x_d(s) = \sum_a d(s, a)$ ，在 $x_d(s) > 0$ 处定义 $\pi_d(a | s) = d(s, a)/x_d(s)$ ，零占用状态任意选行动。记相应转移矩阵为 $\mathbf{P}_{\pi_d}$ ，状态占用列向量为 $\mathbf{x}_d$ ，则流量方程为

$$\mathbf{x}_d = (1 - \gamma) \boldsymbol{\mu}_0 + \gamma \mathbf{P}_{\pi_d}^\top \mathbf{x}_d.$$

$\mathbf{P}_{\pi_d}$ 为行随机矩阵， $\mathbf{I} - \gamma \mathbf{P}_{\pi_d}^\top$ 的 Neumann 级数收敛，因为 $\|\gamma \mathbf{P}_{\pi_d}^\top\|_1 = \gamma < 1$ 。所以此方程唯一可解。实际执行 π_d 所产生的状态占用满足同一方程，必等于 $\mathbf{x}_d$ ；再乘 $\pi_d(a | s)$ 即恢复原来的 $d(s, a)$ 。因此对偶变量不是虚构的频率，而是可实施平稳随机策略的真实折扣访问分布。

互补松弛给出

$$d^*(s, a) > 0 \implies V^*(s) = c(s, a) + \gamma \sum_{s'} P(s' | s, a) V^*(s').$$

最优访问中实际使用的行动必须达到 Bellman 最小值。若不乘归一化因子 $1 - \gamma$ ，流量方程起点项应为 μ_0 ，总质量为 $1/(1 - \gamma)$ ，目标也须同步改变。连续状态下，占用成为测度、价值约束成为函数不等式；可测选择、紧致性和闭性等条件仍需另证，不能只将求和改成积分便宣称强对偶成立。

15.4.2.4 线性二次成本下的有限时域策略

有限 MDP 通过逐行动枚举求最小值，线性二次模型则能利用代数结构直接求出最小行动。前章定义 14.10 已经给出有限时域 LQR 的问题，定

理 14.11 完整建立了 Riccati 递推及最优反馈。这里可以沿用前章的结果, 进一步说明它如何给出当前策略的继续价值。

该模型的最优继续价值具有 $V_t^*(\mathbf{x}) = \mathbf{x}^\top \mathbf{P}_t \mathbf{x} + \beta_t$ 的形式。式 (14.14) 是本节 Bellman 原理在连续线性状态上的具体版本: 线性动态代入下一步二次价值, 仍得到关于当前状态和行动的二次函数; 前章通过严格正定的行动二次项求得式 (14.15) 的反馈增益, 并由式 (14.16) 反向计算 $\mathbf{P}_t$ 。零均值独立加性噪声的影响计入式 (14.17) 的价值常数, 不应在计算期望成本时丢弃。

给定反馈的评价只需代入该反馈; 求最优反馈才需要对二次行动项最小化。有限时域的最优性来自剩余成本的完整比较, 不能推出无限时域闭环稳定; 后者使用前章定理 14.12 的稳定化条件。共同温度例的总输入成本也提醒我们, 换成偏移输入 $(u - 0.4)^2$ 会改变目标。若使用偏差坐标, 应将原成本中的常数项和一次项一并变换, 不能只套一个零目标 LQR 公式。

15.4.3 连续演化下的策略优化

连续时间仍使用“当前一段成本加剩余最优价值”的原理, 只是这一段可以任意短。缩短时间间隔后, 确定性速度产生价值的一阶导数, 扩散噪声留下二阶导数。方程给出局部关系, 验证定理再把它与整段轨迹的最优性连接起来。

15.4.3.1 确定性轨迹的价值方程

考虑从 $(\mathbf{x}, t)$ 出发的受控系统 with 成本

$$\dot{\mathbf{x}}(s) = \mathbf{f}(\mathbf{x}(s), \mathbf{u}(s), s), \quad \mathbf{x}(t) = \mathbf{x}, \quad (15.43)$$

$$J_{t,\mathbf{x}}(\mathbf{u}) = \phi(\mathbf{x}(T)) + \int_t^T \ell(\mathbf{x}(s), \mathbf{u}(s), s) ds. \quad (15.44)$$

状态属于 $\mathbb{R}^n$, 动作属于非空集合 U 。允许控制须可测、满足动作及状态约束, 并使轨迹在所考察时段存在、成本有限; 反馈还须可由已有信息实现。例如局部 Lipschitz 动态和适当增长界可用于保证常微分方程的适定性, 但写出一个不连续反馈后仍需重新核验。定义最优价值 $V(\mathbf{x}, t) = \inf_{\mathbf{u}} J_{t,\mathbf{x}}(\mathbf{u})$ 。

若控制类对截断和前后拼接封闭, 且具有所需近似最优选择, 动态规划关系为

$$V(\mathbf{x}, t) = \inf_{\mathbf{u}|_{[t, t+\Delta]}} \left\{ \int_t^{t+\Delta} \ell(\mathbf{x}(s), \mathbf{u}(s), s) ds + V(\mathbf{x}(t+\Delta), t+\Delta) \right\}. \quad (15.45)$$

理由分为两边: 任意全程控制的后半段成本不小于到达状态的最优继续价值, 所以全程下确界不小于右侧; 反之将近似最优的短段与到达状态的近似最优继续控制拼接, 再使误差趋零, 给出反向不等式。一般状态空间必

须保证这些继续选择可测，不能只对每条路径分别宣称存在一个后续控制。

经典方程的推导另假设 $V \in C^1$ 、动态规划成立，且 $\mathbf{f}, \ell$ 的连续性使短时轨迹偏移为 $O(\Delta)$ 。对参与逼近的控制还要求下面余项局部一致；紧致动作集与相应局部有界连续系数是常见的充分条件。以下在无状态约束的空间或约束不活跃的内部推导，保证所用常值动作在足够短的区间可行；约束边界需另配边界条件。先用任意常值动作 $\mathbf{u}$,

$$\begin{aligned} V(\mathbf{x}(t + \Delta), t + \Delta) &= V(\mathbf{x}, t) + \Delta \partial_t V(\mathbf{x}, t) \\ &\quad + \Delta \nabla_{\mathbf{x}} V(\mathbf{x}, t)^\top \mathbf{f}(\mathbf{x}, \mathbf{u}, t) + o(\Delta), \\ \int_t^{t+\Delta} \ell(\mathbf{x}(s), \mathbf{u}, s) ds &= \Delta \ell(\mathbf{x}, \mathbf{u}, t) + o(\Delta). \end{aligned}$$

用该控制代入下确界，只能先得到

$$-\partial_t V(\mathbf{x}, t) \leq \ell(\mathbf{x}, \mathbf{u}, t) + \nabla_{\mathbf{x}} V(\mathbf{x}, t)^\top \mathbf{f}(\mathbf{x}, \mathbf{u}, t).$$

它对所有 $\mathbf{u} \in U$ 成立，所以左侧不超过右侧的动作下确界。要得到等式，还需要另一个方向，而不能把“任意动作”直接改写成“最优动作”。

固定 $\eta > 0$ ，取短段目标距下确界不超过 $\eta\Delta$ 的允许控制。沿轨迹使用链式法则，短段成本与价值增量等于 $\int_t^{t+\Delta} (\ell + \partial_s V + \nabla V^\top \mathbf{f}) ds$ 。一致余项允许把状态与时间冻结在 $(\mathbf{x}, t)$ ；每个瞬时动作的 Hamilton 量均不低于其动作下确界，于是

$$\partial_t V(\mathbf{x}, t) + \inf_{\mathbf{u} \in U} \{ \ell(\mathbf{x}, \mathbf{u}, t) + \nabla_{\mathbf{x}} V(\mathbf{x}, t)^\top \mathbf{f}(\mathbf{x}, \mathbf{u}, t) \} \leq \eta + o(1).$$

先令 $\Delta \downarrow 0$ 、再令 $\eta \downarrow 0$ ，与前一方向合并得到 Hamilton–Jacobi–Bellman 方程 (HJB)：

$$-\partial_t V(\mathbf{x}, t) = \inf_{\mathbf{u} \in U} \{ \ell(\mathbf{x}, \mathbf{u}, t) + \nabla_{\mathbf{x}} V(\mathbf{x}, t)^\top \mathbf{f}(\mathbf{x}, \mathbf{u}, t) \}, \quad V(\mathbf{x}, T) = \phi(\mathbf{x}). \quad (15.46)$$

花括号中的 Hamilton 量把瞬时成本和沿当前速度的价值变化率相加，不是动力系统中沿轨迹守恒的 Hamilton 能量函数。成本最小化对应这里的 $\inf$ 和 $-\partial_t V$ ；收益最大化须同步改换符号⁴。

定理 15.18 确定性 HJB 验证定理 设候选 $V \in C^1$ 满足式 (15.46) 及终端条件。假设每个允许控制都产生存在到 T 的轨迹，沿轨迹的链式法则和成本积分成立。若有可实现反馈 $\mathbf{u}^* = \kappa(\mathbf{x}, t)$ 逐点达到 HJB 下确界，且闭环轨迹存在到 T 并满足所有可行条件，则 V 为最优价值， κ 为最优反馈。

⁴ M. Bardi, I. Capuzzo-Dolcetta, *Optimal Control and Viscosity Solutions of Hamilton–Jacobi–Bellman Equations*, Birkhäuser, 1997

证明. 任取允许控制, HJB 的下确界不大于代入该动作的值, 所以沿轨迹

$$\partial_s V(\mathbf{x}(s), s) + \nabla_{\mathbf{x}} V(\mathbf{x}(s), s)^\top \mathbf{f}(\mathbf{x}(s), \mathbf{u}(s), s) + \ell(\mathbf{x}(s), \mathbf{u}(s), s) \geq 0.$$

前两项由链式法则合为 $dV(\mathbf{x}(s), s)/ds$. 从 t 积分到 T , 用终端条件得到 $J_{t,\mathbf{x}}(\mathbf{u}) \geq V(\mathbf{x}, t)$. 因而候选值是所有允许成本的下界. 对 κ , 逐点达到下确界使不等式处处取等号, 积分后 $J_{t,\mathbf{x}}(\kappa) = V(\mathbf{x}, t)$, 所以它达到共同下界, 完成验证. ■

HJB 描述光滑最优价值在每个位置的局部关系; 验证定理则证明, 满足方程和相应条件的候选函数确实等于整段轨迹的最优成本. 只在若干采样点降低方程残差还不够, 还需终端或边界条件、极小动作的可实现性、轨迹存在性及整个相关区域上的方程关系.

15.4.3.2 随机轨迹的价值方程

随机轨迹无法逐条预先选择, 但可以优化允许策略的期望成本. 设 $\mathbf{W}_s$ 为 d 维标准 Brownian 运动, 状态满足

$$d\mathbf{X}_s = \mathbf{f}(\mathbf{X}_s, \mathbf{u}_s, s) ds + \Sigma(\mathbf{X}_s, \mathbf{u}_s, s) d\mathbf{W}_s, \quad (15.47)$$

其中 Σ 为 $n \times d$ 矩阵. 允许控制对给定滤过渐进可测, 不得使用未来 Brownian 增量, 并满足解存在、约束与成本可积的要求. 价值为 $\inf_{\mathbf{u}} \mathbb{E}_{t,\mathbf{x}}[\phi(\mathbf{X}_T) + \int_t^T \ell(\mathbf{X}_s, \mathbf{u}_s, s) ds]$; 下标表示从 $(t, \mathbf{x})$ 重启过程, 避免对零概率初态事件直接作比值条件化.

对 $V \in C^{2,1}$ 应用第 13 章的 Itô 公式, 固定动作的受控生成元为

$$\mathcal{L}^{\mathbf{u}} V = \nabla_{\mathbf{x}} V^\top \mathbf{f} + \frac{1}{2} \text{tr}(\Sigma \Sigma^\top \nabla_{\mathbf{x}}^2 V).$$

随机积分在可积鞅条件下的条件均值为零, 二次变差却留下了二阶项. 在动态规划、近似最优选择及局部一致的短时展开条件下, 先代入常值动作得到一个方向, 再沿 $\eta\Delta$ -最优控制积分并令 Δ, η 趋零, 得到

$$\begin{aligned} -\partial_t V(\mathbf{x}, t) = \inf_{\mathbf{u} \in U} \Big\{ & \ell(\mathbf{x}, \mathbf{u}, t) + \nabla_{\mathbf{x}} V(\mathbf{x}, t)^\top \mathbf{f}(\mathbf{x}, \mathbf{u}, t) \\ & + \frac{1}{2} \text{tr}[\Sigma(\mathbf{x}, \mathbf{u}, t) \Sigma(\mathbf{x}, \mathbf{u}, t)^\top \nabla_{\mathbf{x}}^2 V(\mathbf{x}, t)] \Big\}. \end{aligned} \quad (15.48)$$

终端条件仍为 $V(\mathbf{x}, T) = \phi(\mathbf{x})$. 这里对随机微分方程仅取均值后代入确定性 HJB, 会遗漏扩散项.

定理 15.19 随机 HJB 验证 设 V 对状态二次、对时间一次连续可微, 满足式 (15.48) 及终端条件。假设每个允许控制都使受控过程存在到 T , 成本与 Itô 公式中的有限变差项可积, 且 $\int_t^s \nabla_x V^\top \Sigma dW$ 为真鞅。若可容许反馈 $u^* = \kappa(x, t)$ 逐点达到 HJB 下确界, 则 V 等于最优期望成本, κ 达到该值。

证明. 对任意允许控制, HJB 给出 $\partial_s V + \mathcal{L}^{u_s} V + \ell(X_s, u_s, s) \geq 0$ 。沿轨迹应用 Itô 公式、积分并取从 (t, x) 出发的期望, 随机积分因真鞅条件消失, 得到

$$\mathbb{E}_{t,x} \left[\phi(X_T) + \int_t^T \ell(X_s, u_s, s) ds \right] \geq V(x, t).$$

对 κ , 生成元不等式取等号, 同一计算证明其期望成本等于共同下界 V 。这验证的是期望最优, 不是每条噪声实现上的路径最优。■

一个常用的充分鞅条件是 $\mathbb{E} \int_t^T \|\Sigma^\top \nabla_x V\|^2 ds < \infty$ 。若只能得到局部鞅, 应先在退出有界区域等停时 τ_n 处停止, 再证明成本积分、 $V(X_{T \wedge \tau_n}, T \wedge \tau_n)$ 等量能合法取极限, 例如使用增长界、矩估计与一致可积性。局部鞅不自动具有零期望, 省略这一步会使验证结论失去依据。

若扩散矩阵与状态、动作都无关, 二次价值的二阶项只增加状态无关的常数, 对应离散式 (14.17) 的现象。若扩散依赖动作, 它直接参与动作最小化; 依赖状态时也可能改变价值形状。因此噪声均值为零并不足以保证反馈不变。

15.4.3.3 线性二次成本下的连续策略

在线性动态 $\dot{x} = Ax + Bu$ 下, 取 $u \in \mathbb{R}^m$, 阶段成本 $\ell(x, u) = x^\top Qx + u^\top Ru$, 终端成本 $\phi(x) = x^\top Q_T x$, 其中 $Q, Q_T \geq 0$ 、 $R > 0$ 。有限时域取平方可积控制, 固定有限矩阵保证线性轨迹存在。试取对称二次候选

$$V(x, t) = x^\top P(t)x, \quad P(T) = Q_T.$$

它是否确为价值要由 HJB 和验证定理确认, 而不是由二次外形决定。有 $\partial_t V = x^\top \dot{P}x$ 、 $\nabla_x V = 2Px$ 。代入 HJB 后动作相关项为 $u^\top Ru + 2x^\top PBu$, 配方得

$$\begin{aligned} u^\top Ru + 2x^\top PBu &= (u + R^{-1}B^\top Px)^\top R(u + R^{-1}B^\top Px) \\ &\quad - x^\top PBR^{-1}B^\top Px. \end{aligned}$$

正定 R 使第一项非负且仅在一个动作处为零, 因此反馈为

$$u^*(t) = -R^{-1}B^\top P(t)x(t). \quad (15.49)$$

把最小项代回，对所有 $\mathbf{x}$ 比较二次型系数，得到

$$-\dot{\mathbf{P}} = \mathbf{Q} + \mathbf{A}^\top \mathbf{P} + \mathbf{P}\mathbf{A} - \mathbf{P}\mathbf{B}\mathbf{R}^{-1}\mathbf{B}^\top \mathbf{P}, \quad \mathbf{P}(T) = \mathbf{Q}_T. \quad (15.50)$$

这是微分 Riccati 方程；价值边界给在终点，故从 T 向较早时刻反向积分。

有限时域上这些条件也保证不会在中途丢失所需解。矩阵常微分方程先在终端附近有唯一局部对称解；在其存在区间，反馈连续，验证定理说明其二次型为非负最优成本，并不大于零控制的有限成本。零控制在整个有限区间给出统一的二次上界，于是 $\mathbf{0} \leq \mathbf{P}(t) \leq \mathbf{M}\mathbf{I}$ ，某个有限 M 适用于该区间。局部 Lipschitz 的 Riccati 向量场因解有界而可继续延伸，直到起点。因此该候选及反馈确实定义在整个有限时域。

还可以直接算出任意控制与最优控制的成本差。用 Riccati 方程化简沿任意允许轨迹的价值导数，得到

$$\ell(\mathbf{x}, \mathbf{u}) + \frac{d}{dt}[\mathbf{x}^\top \mathbf{P}(t)\mathbf{x}] = (\mathbf{u} + \mathbf{R}^{-1}\mathbf{B}^\top \mathbf{P}\mathbf{x})^\top \mathbf{R}(\mathbf{u} + \mathbf{R}^{-1}\mathbf{B}^\top \mathbf{P}\mathbf{x}).$$

积分后，任意策略的成本等于初始二次价值加右侧非负积分；反馈使积分为零，最优性由此可以逐项核算。例如 $\dot{x} = u$ 、 $Q = R = 1$ 、 $Q_T = 0$ 时， $P(t) = \tanh(T - t)$ 满足 $-\dot{P} = 1 - P^2$ ，反馈 $u = -\tanh(T - t)x$ ，价值为 $\tanh(T - t)x^2$ 。越接近没有终端惩罚的截止时刻，控制增益越小，这也说明有限时域策略一般依赖时间。

无限时域的代数方程与稳定化条件由前章式 (14.20) 给出，这里不把令 $\dot{\mathbf{P}} = \mathbf{0}$ 当作稳定性证明。连续闭环需要特征值实部为负，离散闭环需要特征值位于单位圆内；CARE 与 DARE 分别服务于这两个问题，不能混用。

15.4.3.4 非光滑与受限信息下的价值方程

最优动作切换时，价值可能连续但没有处处存在的梯度。经典 HJB 在折点不能直接代入，这不表示轨迹成本没有定义。黏性解 (viscosity solution) 用光滑函数从上方或下方接触价值，在接触点检验方程不等式；导数取自测试函数，价值本身可以不可微。

将确定性 HJB 写成

$$F(\mathbf{x}, t, a, \mathbf{p}) := -a - \inf_{\mathbf{u} \in U} \{\ell(\mathbf{x}, \mathbf{u}, t) + \mathbf{p}^\top \mathbf{f}(\mathbf{x}, \mathbf{u}, t)\} = 0,$$

其中 a 代表时间导数， $\mathbf{p}$ 代表状态梯度。

定义 15.20 连续价值函数的黏性解 设 V 在方程作用域内连续。对任意光滑测试函数 φ ，若 $V - \varphi$ 在内点 (x, t) 取局部最大值时均有 $F(x, t, \partial_t \varphi, \nabla_x \varphi) \leq 0$ ，称 V 为黏性次解。若局部最小值处均有相应的 $F \geq 0$ ，称为黏性上解。同时满足两项，并按当前问题满足终端或边界条件的 V 称为黏性解。

可将测试函数平移常数使接触时 $V = \varphi$ 。局部最大对应 φ 从上方接触，局部最小对应从下方接触；不是任取一个斜率代入。随机二阶方程还需代入测试函数的 Hessian。光滑 V 取 $\varphi = V$ 即恢复经典等式。适当的比较原理可由次解不高于上解推出唯一性，但其方程结构、连续性、增长与边界条件仍需另证，定义本身不保证唯一或易于计算。

先看目标边界上的非光滑。令 $\dot{x} = u, |u| \leq 1$ ，每单位时间成本为 1，到达 $\{0\}$ 即终止，则最短到达时间 $V(x) = |x|$ 。在延续域 $x \neq 0$ 上，

$$0 = 1 + \inf_{|u| \leq 1} V'(x)u = 1 - |V'(x)|.$$

正侧取 $u = -1$ 、负侧取 $u = 1$ ，均推向原点。 $x = 0$ 是退出边界，只需施加 $V(0) = 0$ ，不属于方程内部。这个例子不能单独证明内点必须使用黏性解；要展示内点折角，需要一个不在原点提前退出的问题。

示例 15.21 延续域内部的价值折点 仍取 $\dot{x} = u, |u| \leq 1$ ，改为固定终点 T 、零运行成本和终端成本 $|x(T)|$ 。剩余时间最多移动 $T - t$ ，故

$$V(x, t) = \max\{|x| - (T - t), 0\}, \quad -V_t + |V_x| = 0, \quad V(x, T) = |x|.$$

内侧 $|x| < T - t$ 可以到达原点并停留，价值为零；外侧只能减少 $T - t$ 的距离。折点 $x = \pm(T - t)$ 位于 $t < T$ 的延续域内部。例如 $T - t = 1$ 时， $|x| \leq 1$ 可完全纠正， $x = 1.5$ 仍剩终端代价 0.5。

正侧折点附近 $V = \max\{x + t - T, 0\}$ 。从下方接触的光滑函数的导数对 (φ_x, φ_t) 为 (p, p) 、 $0 \leq p \leq 1$ ，即两侧斜率的凸组合，故 $-\varphi_t + |\varphi_x| = -p + p = 0$ ，满足上解条件。向上折角不存在光滑上方接触函数，次解检验在该点无额外约束；光滑区域满足经典等式。负侧接触导数为 $(-p, p)$ ，同样满足等式。这说明黏性条件能处理方程内部的切换折点，而不把切换面误当作退出边界。

有状态约束时，价值只在可行控制存在的区域定义。不可穿越边界需配合可行方向或状态约束边界条件；允许触边退出则需退出成本。内部方程相同不能代替边界含义。真实状态不可见时，也不能直接以 x 作为反馈输入，一般须使用观测历史给出的信念状态，通常是无限维分布。线性高斯二次模型的有限维分离是特殊结构，将在下一节证明其成本最优性。

HJB 比较累计成本，前章的屏障约束限定安全行动。将屏障二次规划用于修正一个性能反馈，通常会改变原成本最优性；在 HJB 中直接加入约束则是另一个受约束优化问题。稳定性证明使用的 Lyapunov 函数、最优价值和屏障函数分别服务于收敛、最优与不变性，不能仅因它们都考察沿轨迹的标量变化而互换。

15.4.4 受限信息下的策略选择

15.4.4.1 新增观测下的决策收益

前面的最优规则都受到已有信息限制。如果先获得一次观测，后面的行动可能随观测改变，这项改进能否抵偿获取成本？答案依赖任务损失，不只依赖观测减少了多少不确定性。设未知环境参数为 Θ 、当前信息为 $\mathcal{G}$ ，信念为 $b(d\theta) = \mathbb{P}(\Theta \in d\theta \mid \mathcal{G})$ 。先取有限行动与可测可积损失；立即行动的最小风险为

$$\mathcal{R}(b) = \inf_a \mathbb{E}_{\theta \sim b}[\ell(a, \theta)].$$

现在可先从给定核 $K(dz \mid \theta)$ 观察信号 Z ，得到后验 b_Z ，再选适合该后验的行动。

定义 15.22 期望样本信息价值 在上述有限行动、可积损失和信号核条件下，期望样本信息价值（expected value of sample information, EVSI）为

$$\text{EVSI}(Z \mid b) = \mathcal{R}(b) - \mathbb{E}_{Z \mid b}[\mathcal{R}(b_Z)]. \quad (15.51)$$

观察后的 $\inf_a$ 在对 Z 求期望之内：先见信号、再行动。若把 $\inf_a$ 放在外面，就强迫所有信号结果使用同一行动，丢失信息的用途。这比较的是两种信息条件下的最优值，不是同一固定策略多观测一次后的数值变化。

EVSI 非负，因为看到信号后总可忽略它。若原最优行动为 a^* ，则

$$\mathcal{R}(b_Z) \leq \mathbb{E}[\ell(a^*, \Theta) \mid Z = z, \mathcal{G}].$$

对 Z 平均并用塔式法则，得到 $\mathbb{E}_{Z \mid b}[\mathcal{R}(b_Z)] \leq \mathbb{E}[\ell(a^*, \Theta) \mid \mathcal{G}] = \mathcal{R}(b)$ 。一般行动空间若下确界不达到，可用风险至多 $\mathcal{R}(b) + \varepsilon$ 的行动，作同样比较后令 $\varepsilon \downarrow 0$ ；但观察后的选择还须具有可测的最优或近似最优规则。免费信息不降低最优收益，不意味着有成本的信息都值得购买：获取成本为 k 时，净价值是 $\text{EVSI} - k$ 。

若直接知道 Θ ，完全信息价值为

$$\text{EVPI}(b) = \inf_a \mathbb{E}_b[\ell(a, \Theta)] - \mathbb{E}_b[\inf_a \ell(a, \Theta)]. \quad (15.52)$$

已知 Θ 可模拟信号核，再执行任何基于信号的规则，故 $0 \leq \text{EVSI} \leq \text{EVPI}$ 。等号 $\text{EVSI} = \text{EVPI}$ 表示信号已保留实现该任务最优行动所需的信息，不要求重建参数的每个细节。

示例 15.23 辨别信号与无关信号 阳性概率为 0.3，假阳性损失为 1、假阴性为 9。不取新信号时，两行动风险为 0.7 和 2.7，所以 $\mathcal{R}(b) = 0.7$ 。免费信号 Z_{perf} 若完全揭示类别，观察后总能选对，风险为零，EVSI 为 0.7。独立于类别的公平硬币 Z_{coin} 不改变后验、行动或风险，EVSI 为零。若完全信号成本为 0.8，其净价值为 -0.1 。信息能否辨别类别、是否改善任务、是否抵偿获取成本，是三个不同判断。

互信息衡量关于 Θ 的不确定性平均减少多少，EVSI 衡量给定损失下最优决策改善多少。信号可能精确揭示与行动无关的参数，互信息大而 EVSI 为零；另一个信号只在决策阈值附近改变信念，却可能避免高代价行动。对数评分下，若行动本身是预测分布，最优期望对数损失与条件熵对应，才得到信息增益与风险改善的直接联系。一般分类、分配和控制损失没有这种自动等价；使用熵作为查询代理，需要额外论证它与任务成本的关系。

15.4.4.2 未知收益下的探索价值

信息不一定来自独立购买的信号，也可能来自行动自身的结果。考虑连续两轮从两个备选方案中选择一个，每次成功奖励 1、失败奖励 0。在多臂问题中，每个备选方案称为一个“臂”。本小节改用收益最大化，对应成本为奖励的负值。已知臂的成功概率为 0.6；未知臂有一个两轮不变的参数 $\Theta \in \{0.3, 0.9\}$ ，先验各为 $1/2$ 。给定 Θ ，各次奖励条件独立，已知臂结果不提供 Θ 的信息。每轮只看到所选臂结果，不看到未选臂的反事实结果。

两臂当前平均成功率均为 0.6，只比第一轮即时收益会并列。先选未知臂时，成功的边缘概率为 0.6。看到成功后，

$$\mathbb{P}(\Theta = 0.9 \mid \text{成功}) = \frac{0.9 \times 0.5}{0.9 \times 0.5 + 0.3 \times 0.5} = 0.75,$$

未知臂下一轮成功率为 $0.75 \times 0.9 + 0.25 \times 0.3 = 0.75$ ，应继续选它。若看到失败，

$$\mathbb{P}(\Theta = 0.9 \mid \text{失败}) = \frac{0.1 \times 0.5}{0.1 \times 0.5 + 0.7 \times 0.5} = 0.125,$$

未知臂后验成功率为 $0.125 \times 0.9 + 0.875 \times 0.3 = 0.375$ ，下一轮应改选已知臂。因此两轮最优适应行动的期望收益为

$$0.6 + 0.6 \times 0.75 + 0.4 \times 0.6 = 1.29. \quad (15.53)$$

先选已知臂不会更新信念，第二轮仍并列，两轮收益为 1.2。多出的 0.09 来自第一轮观测改善第二轮选择，不来自未知臂的当前均值较高。

这就是探索 (exploration) 的决策作用：行动同时影响当前收益和未来信息。只剩一轮时，信息没有使用机会，两臂又并列；试验成本、先验或剩余时域改变，探索价值也会改变。若每轮同时看到所有臂，或 Θ 随时间漂移，上述信息结构已不成立，后验和 1.29 的计算也不再适用。一般多臂和强化学习算法还须处理长期规划、未知参数与计算复杂度，这个两轮例子只定位信息价值从哪里进入策略。

自适应查询也改变统计证据的条件。因为过去观察决定下一次试验或停止时间，不能把选中样本无条件视为固定设计下的独立同分布数据。报告置信区间或最优行动识别保证时，应回用第 10.4.5 节的停时条件与第 10.4.5.3 节的可预测设计，检查行动是否在当前噪声揭晓前选定，以及误差保证是否对全部查看时刻同时成立。

探索带来的长期代价，还可以与“已知真实环境参数、每轮都选最佳行动”的基准比较。这一比较称为遗憾，基准与前面的信息价值不同。令 Y_t 为第 t 轮奖励， $\mathcal{H}_{t-1}$ 为行动前信息，行动 A_t 在 Y_t 揭晓前选定，并假设对固定环境参数 θ ,

$$\mathbb{E}[Y_t | \mathcal{H}_{t-1}, A_t = a, \Theta = \theta] = \mu(a, \theta) \quad \text{几乎处处.}$$

这里平均奖励不随轮次改变；条件均值假设使自适应选择后当前噪声仍正确中心化，却不使访问次数或全部数据变成非自适应。令 $a^*(\theta) \in \arg \max_a \mu(a, \theta)$ ，累计伪遗憾为

$$\text{Reg}_T(\theta) = \sum_{t=1}^T [\mu(a^*(\theta), \theta) - \mu(A_t, \theta)].$$

它比较同一环境下的平均奖励，而不是两条实现奖励轨迹之差。算法和参数随机时还可再取期望；直接用实现奖励定义的遗憾含有奖励噪声。一次信号的 EVSI 与长期伪遗憾相关，但前者不能替代后者的统计与序贯证明。

15.4.4.3 线性高斯条件下的估计与行动分离

一般情况下，行动改变未来信息，会像探索例那样同时影响估计和控制。一个重要的例外是标准有限时域线性二次高斯控制 (LQG)。取

$$\mathbf{x}_{t+1} = \mathbf{A}\mathbf{x}_t + \mathbf{B}\mathbf{u}_t + \mathbf{w}_{t+1}, \quad \mathbf{y}_t = \mathbf{C}\mathbf{x}_t + \mathbf{v}_t,$$

其中 $\mathbf{x}_0$ 高斯， $\mathbf{w}_{t+1} \sim \mathcal{N}(\mathbf{0}, \mathbf{W}_t)$ 、 $\mathbf{v}_t \sim \mathcal{N}(\mathbf{0}, \mathbf{N}_t)$ ， $\mathbf{W}_t \geq \mathbf{0}$ 、 $\mathbf{N}_t > \mathbf{0}$ ，初态与所有噪声相互独立，噪声跨时独立，协方差已知且不依赖控制。先观察 $\mathbf{y}_t$ 再行动，信息为 $\mathcal{I}_t = \sigma(\mathbf{y}_0, \mathbf{u}_0, \dots, \mathbf{u}_{t-1}, \mathbf{y}_t)$ 。允许无输入或状态约束、具有有限二阶矩的 $\mathcal{I}_t$ -可测控制；若使用私有随机数，也将独立于系统噪声

的已用随机数计入可用信息。目标为前章有限 LQR 的期望二次成本，状态和终端权重半正定、输入权重正定。

第 13.5.2 节的有限时域 Kalman 递推给出 $\hat{\mathbf{x}}_t = \mathbb{E}[\mathbf{x}_t | \mathcal{I}_t]$ 和更新后误差协方差 $\mathbf{E}_t = \mathbb{E}[(\mathbf{x}_t - \hat{\mathbf{x}}_t)(\mathbf{x}_t - \hat{\mathbf{x}}_t)^\top | \mathcal{I}_t]$ 。令 $\mathbf{e}_t = \mathbf{x}_t - \hat{\mathbf{x}}_t$ ，投影性质说明 $\mathbb{E}[\mathbf{e}_t | \mathcal{I}_t] = \mathbf{0}$ ，从而

$$\mathbb{E}[\mathbf{x}_t^\top \mathbf{Q}_t \mathbf{x}_t | \mathcal{I}_t] = \hat{\mathbf{x}}_t^\top \mathbf{Q}_t \hat{\mathbf{x}}_t + \text{tr}(\mathbf{Q}_t \mathbf{E}_t).$$

交叉项的条件期望为零，因而无条件也有 $\mathbb{E}[\hat{\mathbf{x}}_t^\top \mathbf{Q}_t \mathbf{e}_t] = 0$ 。标准模型的关键在于 $\mathbf{E}_t$ 由 Kalman 协方差递推确定，不依赖观测值或所选控制。控制在预测均值中作为已知平移被扣除，不改变下一次观测的误差协方差。

只看这一项分解还不能证明全程最优，需要把所有未来动作的影响合在一起。令 $\mathbf{P}_t, \mathbf{K}_t$ 取前章有限 LQR 递推的结果， $\mathbf{M}_t = \mathbf{R}_t + \mathbf{B}^\top \mathbf{P}_{t+1} \mathbf{B} > \mathbf{0}$ 。回用前章逐步配方并对时间求和，任一允许输出策略 μ 满足

$$\begin{aligned} J^\mu &= \mathbb{E}[\mathbf{x}_0^\top \mathbf{P}_0 \mathbf{x}_0] + \sum_{t=0}^{H-1} \text{tr}(\mathbf{P}_{t+1} \mathbf{W}_t) \\ &\quad + \sum_{t=0}^{H-1} \mathbb{E}[(\mathbf{u}_t + \mathbf{K}_t \mathbf{x}_t)^\top \mathbf{M}_t (\mathbf{u}_t + \mathbf{K}_t \mathbf{x}_t)]. \end{aligned}$$

此式来自状态价值项的望远镜消去和独立零均值噪声的迹项，不是假设输出策略已经最优。再对 $\mathcal{I}_t$ 条件化，最后一项逐步分为

$$\begin{aligned} &\mathbb{E}[(\mathbf{u}_t + \mathbf{K}_t \mathbf{x}_t)^\top \mathbf{M}_t (\mathbf{u}_t + \mathbf{K}_t \mathbf{x}_t) | \mathcal{I}_t] \\ &= (\mathbf{u}_t + \mathbf{K}_t \hat{\mathbf{x}}_t)^\top \mathbf{M}_t (\mathbf{u}_t + \mathbf{K}_t \hat{\mathbf{x}}_t) + \text{tr}(\mathbf{K}_t^\top \mathbf{M}_t \mathbf{K}_t \mathbf{E}_t). \end{aligned}$$

所有迹项与初态项都不依赖策略。剩余各项非负，而可实施策略

$$\mathbf{u}_t^* = -\mathbf{K}_t \hat{\mathbf{x}}_t \quad (15.54)$$

使这些项同时为零，因而在全部允许输出策略中达到最小期望成本。误差协方差产生的成本并未消失，只是不能通过该模型中的控制改变。

这就是分离原则：有限 Kalman 滤波按估计误差构造条件均值，LQR 增益按行动成本构造，再将二者连接。它比确定性观测器的谱分离多给出成本最优性，却不要求有限时域滤波已经达到稳态；稳态滤波和输出反馈的稳定条件仍由前章负责。受控观测、动作相关噪声、风险敏感目标、输入或状态约束会改变上述分解或可行性，不能直接沿用这一结论。温度例中的有界两点噪声也不是这里的高斯假设；若采用 LQG 模型，应显式另取独立高斯噪声，并放弃将有界安全区间视为逐路径必然保证。

15.4.5 风险约束下的策略优化

前面已经说明怎样计算指定策略的风险，现在进一步允许改变动作来降低风险。必须先固定目标：嵌套条件风险可以按其定义逐步优化；静态总损失 CVaR 使用累计状态；概率约束和候选模型又分别规定可行策略与最坏机制。这些问题的目标和可行策略不同，因此下面分别说明需要保留哪些状态信息、在递推中如何比较动作，以及什么条件保证算出的值确实属于原问题。

对有限状态行动、确定 Markov 策略和具有充分状态信息的嵌套风险，单调性允许把每个下一状态的最优继续值用于当前比较：

$$\begin{aligned} V_H(s) &= c_H(s), \\ V_t(s) &= \min_{a \in \mathcal{A}(s)} \{c_t(s, a) + \rho_{t,s,a}(V_{t+1}(S_{t+1}))\}. \end{aligned} \quad (15.55)$$

有限时域的证明仍是逆向归纳，但将期望的保序性换成风险映射的单调性。任一允许的历史依赖确定策略，其后续风险逐节点不低于 V_{t+1} ，当前风险便不低于相应动作项；取最小动作再接上各节点的最优继续策略达到此界。这要求允许规则能逐历史拼接、风险模型在相同状态使用相同映射。取条件期望恢复普通 Bellman；取条件 CVaR 得到嵌套 CVaR，而非静态 CVaR⁵。

若允许随机行动并采用第 15.3.3.1 节“先评价环境风险、再平均行动风险”的口径，行动概率的目标为各动作项的线性组合，确定最小动作仍足够。若声明风险作用于行动和下一状态的联合损失，则应优化概率分布 $q \in \Delta(\mathcal{A}(s))$ ：

$$\inf_q \rho_{t,s}^q(c_t(s, A) + V_{t+1}(S')).$$

不能无条件用期望的线性性把它写成动作风险的平均，再声称确定策略最优。给定更具体的风险泛函可另证随机化是否有益；本节上式 (15.55) 的策略范围以已声明的口径为准。

无限折扣版本明确按“后续风险值再乘折扣”的目标定义算子

$$(T_\rho V)(s) = \min_a \{c(s, a) + \gamma \rho_{s,a}(V(S'))\}. \quad (15.56)$$

成本有界、每个映射归一化、单调且平移等变时，第 15.3.3.1 节已证一步风险非扩张；再用最小值差不等式得到

$$\|T_\rho V - T_\rho W\|_\infty \leq \gamma \|V - W\|_\infty. \quad (15.57)$$

因此 $\gamma < 1$ 时唯一固定点存在，价值迭代误差不超过 $\gamma^k \|V^{(0)} - V_\rho^*\|_\infty$ ，残差界为 $\|T_\rho V - V\|_\infty / (1 - \gamma)$ 。

⁵ A. Ruszczyński, *Risk-Averse Dynamic Programming for Markov Decision Processes In Mathematical Programming*, 2010, vol. 125, no. 2, pp. 235–261

最优解释还须补全。固定点的贪心策略使固定策略风险算子取同一个固定点，故达到该值。有限截断问题用上述逆向归纳比较全部允许历史策略；若 $|c| \leq C$ ，归一化和非扩张使第 n 步以后的折扣风险影响至多为 $\gamma^n C/(1-\gamma)$ ，统一趋于零。因此截断最优值和各允许策略的截断值可取极限，得到固定点不大于任何策略的无限嵌套风险。如果原风险目标并非如此递归、状态遗漏历史信息或策略类不可拼接，算子即使压缩，也只是稳定地计算另一个问题。

相干映射的包络把动作项改写成

$$c(s, a) + \gamma \sup_{q \in Q(s, a)} \sum_{s'} q(s' | s, a) V(s').$$

将它解释为逐时鲁棒最优，必须使用定义 15.10 的矩形候选机制。共享未知参数的非矩形集合不能逐节点自由取最坏；有限凸风险若有对偶罚项，也不能在优化时删去。

静态 CVaR 则回用第 15.3.3.2 节的累计状态。固定 η ，将式 (15.23) 中的行动概率汇总改成行动最小化，得到

$$W_t^\eta(s, b) = \min_a \sum_{s'} P_t(s' | s, a) W_{t+1}^\eta(s', b + \gamma^t c_t(s, a)),$$

$$W_H^\eta(s, b) = (b + \gamma^H c_H(s) - \eta)_+.$$

随后计算

$$\inf_{\pi} \text{CVaR}_{\alpha}(L^{\pi}) = \inf_{\eta \in \mathbb{R}} \left\{ \eta + \frac{1}{1-\alpha} \sum_s \mu_0(s) W_0^\eta(s, 0) \right\}.$$

两层均为下确界，因此交换 $\inf_{\pi}, \inf_{\eta}$ 不需要极小极大定理，但须说明策略类：这里允许时间、物理状态和累计成本上的策略，并假设可测选择与所需达到性。阈值是起点选定的常数，不能到未来看到损失后重新挑选。若原问题只允许不读取累计成本的策略，这项动态规划可能扩大可行策略类；若只存在下确界，可使用近似最优阈值和策略，不能宣称必有最优解。

概率约束问题例如 $\inf_{\pi: \mathbb{P}^{\pi}(E) \leq \varepsilon} \mathbb{E}^{\pi}[L]$ 限制的是特定违规事件 E 。终端、逐时和全程事件须分别定义；全程约束可能需要增广累计违规标记或剩余风险预算。路线例要求 $\mathbb{P}^{\pi}(L > 3) \leq 0.1$ 时，随机策略须满足 $0.2p \leq 0.1$ ，即 $p \leq 1/2$ 。期望损失 $2 - 0.8p$ 在 $p = 1/2$ 取 1.6；若只允许确定行动，则只有稳妥可行，成本 2。随机化的作用来自概率约束的可行比例，不能用无约束纯策略最优结论排除它。

最坏模型目标为

$$\inf_{\pi \in \Pi_{\text{adm}}} \sup_{Q \in \mathcal{P}} \mathbb{E}_Q^{\pi}[L].$$

单步时退化为 $\inf_a \sup_Q \mathbb{E}_Q[\ell(a, Y)]$, 参数模型用 $Q = P_\theta$ 。 Π_{adm} 须规定信息和约束, $\mathcal{P}$ 须规定模型能否随历史改变。对偶、极小极大交换和局部递推分别有自己的条件。评价准则、时间一致性、可行性与计算收敛各回答一项问题, 不能用其中一个替代其他检查。

15.5 本章小结

同一路线任务说明了评价和优化为什么需要分开。策略先规定走捷径的概率 p , 再与环境共同产生概率为 $1-p, 0.8p, 0.2p$ 的三条轨迹; 给每条轨迹计价后, 期望损失为 $2-0.8p$, 尾部指标和违规概率还描述它的其他后果。固定 p 计算这些量是评价, 允许改变 p 才是优化。期望准则选 $p=1$, 概率预算可能要求 $p \leq 1/2$, 因此“最优”离不开准则和可行域。

平均收益、一次实现收益和尾部损失不是同一个对象。VaR 给出分位阈值, CVaR 平均最坏尾部, 并在分位原子上按需要补足概率质量。风险包络重加权既定分布, 模型不确定集改变候选机制, 机会约束限制违规事件。逐时获得信息后, 静态总损失 CVaR 可能发生条件偏好反转; 嵌套风险以单调递归保持时间一致性, 却定义了不同目标。固定策略的风险计算必须说明行动随机性是否也进入风险映射; 逐节点最坏模型还必须与矩形候选集合一致。

期望评价以指定策略的行动概率汇总, Bellman 优化才把它换成行动最小值。有限时域由逆向归纳证明最优性, 有限折扣问题由压缩性、可达到性和全历史策略比较共同完成证明。占用流量把价值下界与可实现访问频率连接起来。连续时间则用 HJB 描述局部最优关系, 并用终端条件、光滑性、轨迹可行性与可积条件验证全程成本; 非光滑内点和状态边界不能省略相应的解概念与边界要求。

新增信息只有通过改变后续行动才产生决策价值。EVS 比较观察前后的最优风险, 探索把即时收益和未来信息放在同一策略中; 在标准有限 LQG 模型的特定条件下, 可以把估计与行动分开设计并保持期望成本最优。温度例同样显示, 误差收敛后仍要比较舒适偏差与能耗成本, 且按总输入 u 计价, 与按偏移输入 $u-0.4$ 计价, 会得到不同的优化问题。

价值迭代收敛描述的是计算序列 $V^{(k)}$, 闭环状态收敛描述的是执行轨迹 x_t , 二者不是同一个时间轴上的同一结论。稳定与安全条件回到前章核实验; 后续多方策略问题还要研究其他参与者同时选择行动时的响应, 以及策略更新序列如何演化。

多方策略的响应与演化

两个人共用一个房间，却分别控制一台加热器。一人增加供热，会提高共同房间的温度，因而同时影响两人的舒适程度和下一步选择。第 14 章研究给定反馈怎样控制状态，第 15 章在既定环境中比较策略价值；现在环境中还有会选择、会调整的参与者。一个人算出的最优策略依赖对方，而对方也在作同样的计算。怎样定义这种相互依赖的选择？双方都愿意维持的策略组合是否存在，实际调整又是否会走到那里？

回答这些问题，须分开三种对象：一局内的行动与状态、给定信息下的完整策略、多局学习形成的策略序列。先确定策略能够依赖什么信息，才能计算其价值和允许的偏离；若任何人单独改变策略都无法提高收益，就满足相应的均衡条件；若还想研究策略会怎样逐轮变化，则必须给出更新规则。即使策略持续变化，也可以比较整个序列与一个固定替代策略的累计表现。温度模型用于区分这几层判断，匹配硬币用于展示随机化与循环，三张牌质询博弈则保留私人信息、完整计划和局部学习之间的联系。合作时还要另问共同收益怎样分配，以及成员是否愿意接受分配。

16.1 策略的多方行动与信息

16.1.1 参与者与联合行动

只写一人的行动还不足以确定房间温度或对局结果，需要把同一时刻所有人的选择放在一起。战略式博弈用参与者、可选行动和各自收益描述这种依赖；它是一张完整的比较规则，尚未规定各人怎样找到行动。

定义 16.1 有限战略式博弈 有限 n 人战略式博弈（strategic-form game）由参与者集合 $N = \{1, \dots, n\}$ 、每人的有限行动集 A_i 和收益函数

$$u_i : A_1 \times \dots \times A_n \rightarrow \mathbb{R}$$

组成，各 A_i 均非空。

联合行动记为 $\mathbf{a} = (a_1, \dots, a_n) \in \prod_i A_i$ 。双人有限行动时，可以把各人的收益列成一张表，从而得到矩阵表示。

定义 16.2 有限矩阵博弈 有限双人矩阵博弈 (matrix game) 由两组非空有限行动 $A_1 = \{1, \dots, m\}$ 、 $A_2 = \{1, \dots, n\}$ 和两张收益矩阵 $U_1, U_2 \in \mathbb{R}^{m \times n}$ 给出。第 1 位参与者选择行，第 2 位参与者选择列，落在 (i, j) 时，两人的收益分别为 $((U_1)_{i,j}, (U_2)_{i,j})$ 。若存在矩阵 M 使 $U_1 = M$ 、 $U_2 = -M$ ，双方收益之和恒为零，就得到 零和博弈 (zero-sum game)。

一个人增加的收益正好是另一个人的损失，因此零和情形只需记录第 1 位参与者的收益矩阵 M ；一般和情形则不能省略第二张矩阵。

温度与能耗通常不满足零和关系。以下温度扩展也使用联合行动，但行动连续，不属于刚才的有限博弈定理的适用范围。

示例 16.3 两方共同加热的状态与成本 沿用温差状态 x_t ，把原单方加热量明确扩为两个输入之和：

$$x_{t+1} = 0.8x_t + u_{1,t} + u_{2,t} + w_{t+1}, \quad y_t = x_t + v_t. \quad (16.1)$$

本章计算先取 $w_{t+1} = v_t = 0$ 。每个局内时刻，双方先观察 $x_t = y_t$ ，再同时选择各自的 $u_{i,t}$ ，两项输入共同推动下一状态；双方作出本次选择时，都还看不到对方本次的行动。后面的交替响应描述跨轮策略更新，不改变这项局内信息约定。默认 $u_{i,t} \in \mathbb{R}$ ，这是允许正负调温的无约束教学模型；若只允许加热或增加安全约束，必须重新求解约束响应。给定局内时域 H ，第 i 方的成本可写成

$$J_i(\pi_1, \pi_2; x_0) = \sum_{t=0}^{H-1} [(x_{t+1} - r_i)^2 + \lambda_i u_{i,t}^2], \quad \lambda_i > 0,$$

其中 π_i 把本人可用历史映射为行动， r_i 是舒适目标， λ_i 是本人能源代价权重。用于最大化的收益为 $-J_i$ ，不是 J_i 。

若双方目标同为 2，维持 $x_t = 2$ 要求总输入为 0.4，并非每人都输入 0.4。对固定反馈 $u_{i,t} = a_i - k_i(x_t - 2)$ ，只有 $a_1 + a_2 = 0.4$ 时，误差才满足

$$x_{t+1} - 2 = (0.8 - k_1 - k_2)(x_t - 2).$$

因此总增益为 0.3 时才复现前章的误差系数 0.5。这只是给定联合反馈后的状态计算，不证明该反馈对任一方最优。两方反馈的选择及更新须另行分析。

16.1.2 纯策略与混合策略

在匹配硬币中，双方同时选正面 H 或反面 T ，相同则第 1 方得 1，不同则得 -1 ，第 2 方收益相反。固定选择某一面会给对方留下针对它的机会，于是需要随机化：用一个概率分布选择行动，而不是在一局里把两个行动各执行一半。

定义 16.4 纯策略与混合策略 直接选择某一行或某一列称为纯策略 (pure strategy)。在行动上选择概率分布称为混合策略 (mixed strategy)。记

$$\Delta_m = \{x \in \mathbb{R}^m : x \geq 0, \mathbf{1}^\top x = 1\}$$

为 m 个行动上的概率单纯形。双方以各自的混合策略独立抽取行动。

对一般有限行动集写作 $\sigma_i \in \Delta(A_i)$ ，联合策略为 $\sigma = (\sigma_1, \dots, \sigma_n)$ ，其余人的策略组合记为 σ_{-i} 。这里“联合策略”是各人的规则集合；若各人独立抽样，联合行动服从乘积分布。如果共同装置抽取一个行动组合，再私下向各人发建议，联合分布可以相关。两种方式即便具有同样的边缘概率，也可能产生不同收益；具体计算见第 16.2.2 节。

单纯形 Δ_m 嵌在 $\mathbb{R}^m$ 中，维数为 $m - 1$ ，顶点对应纯行动。匹配硬币只需一个数 $p \in [0, 1]$ 表示第 1 方选 H 的概率，另一个数 q 表示第 2 方的同类概率。此时的策略空间是正方形，而不是四个纯行动组合。

16.1.3 行动历史与可用信息

矩阵中的一个“行动”有时其实是一整份计划。要判断计划能否执行，需要还原每一步发生的时间与行动者所见的信息。考虑高牌 H 、中牌 M 和低牌 L 。庄家从 H 与 L 中等概率发给参与者 1 一张隐藏牌， M 留作公共比较基准。参与者 1 看到自己的牌后选择质询 B 或放弃 P 。放弃时收益为 0。质询后，参与者 2 只知道发生了质询，不知道隐藏牌，并选择应对 C 或退让 F 。退让时参与者 1 得到 1；应对时，高牌使参与者 1 得到 2，低牌使其得到 -2 。参与者 2 得到相反收益。

这就是本章的三张牌教学任务：只随机发出高、低牌，中牌是公开比较基准，并非第三种可能的私有牌。质询和应对发生在同一局的不同节点；学习算法在下一局改变概率，是另一个时间尺度。

定义 16.5 有限扩展式博弈的历史树 扩展式博弈 (extensive-form game) 用历史树保留这些信息。记 H 为非空有限历史集合, 空历史为 $\emptyset$ 。它满足前缀封闭: 若一串行动属于 H , 删去末尾若干行动所得的前缀仍属于 H 。不能再延长的历史组成终止集合 $Z \subset H$ 。若 $h \notin Z$, 可选行动集合 $A(h)$ 规定合法后继 ha , 参与者函数 $P(h)$ 指出下一步由哪位参与者行动; 机会节点记为 $P(h) = c$, 其行动概率 $\sigma_c(a | h)$ 已给定、非负且在 $A(h)$ 上和为 1。终止历史 z 为每位参与者给出收益 $u_i(z)$ 。对各参与者, 还需指定下面的信息集划分, 才能完整确定博弈。

三张牌质询博弈的机会节点先选择 H 或 L , 概率各为 $1/2$ 。参与者 1 看到牌面, 所以“拿到 H ”与“拿到 L ”属于两个不同决策位置。若他选择 P , 历史立即终止; 若选择 B , 参与者 2 行动。参与者 2 只看到“发生了质询”, 无法区分历史 (H, B) 与 (L, B) 。

对参与者 i , 记全部由其行动的非终止历史为

$$H_i = \{h \in H \setminus Z : P(h) = i\}.$$

定义 16.6 信息集 参与者 i 的信息集 (information set) 族 $\mathcal{I}_i$ 是 H_i 的一个划分, 每个信息集 $I \in \mathcal{I}_i$ 收集参与者当时无法区分的决策历史。同一信息集中的历史必须具有相同的合法行动集, 记这个共同集合为 $A(I) = A(h)$, 其中 $h \in I$ 。

否则参与者连“现在能做什么”都无法由观察确定。牌面例子中, 参与者 2 的信息集为

$$I_2 = \{(H, B), (L, B)\},$$

可选行动都是 $\{C, F\}$ 。信息集不是状态的另一名称。第 15.4.2 节中的 Markov 状态用于预测给定行动后的未来分布; 信息集描述当前参与者无法区分哪些历史。两个节点可以有相同物理状态, 却因参与者记得不同过去而属于不同信息集, 也可以物理状态不同却因观察受限而位于同一信息集。参与者 i 的纯策略必须为每个 $I \in \mathcal{I}_i$ 指定一个 $A(I)$ 中的行动, 包括均衡路径上不会到达的信息集; 因此它是一份完整的应急计划, 而不只是实际走过路径上的动作序列。

表 16.1 将同一个小博弈中“真实发生了什么”和“行动者能区分什么”并列写出。参与者 2 在两条质询历史上必须用同一个 c , 因为他看到的数据相同。若直接为高牌和低牌分别设置 c_H, c_L , 便改变了可用信息, 得到另一个博弈, 即使收益函数没有改动也不能复用当前的均衡。

行动者	真实决策历史	当时可区分的信息	合法行动规则
参与者 1	拿到 H 或拿到 L	私人牌面可见, 属于两个信息集	可分别选 b_H, b_L
参与者 2	(H, B) 或 (L, B)	只看到质询, 属于同一信息集	两条历史共用应对概率 c
机会	初始发牌	已给定的环境随机化	$P(H) = P(L) = 1/2$, 参与者不能选择

表 16.1 三张牌教学博弈的信息约束。 b_H, b_L 为对应牌面上的质询概率, c 为参与者 2 看到质询后的应对概率。这些行为策略记号将在下一小节正式使用。

参与者 2 不能规定“高牌质询就应对, 低牌质询就退让”, 因为他无法区分这两个节点。若公开牌面, 信息集就拆成两个单点集合, 可实施的策略集合已经改变; 不能继续使用隐藏牌博弈的解。对零概率历史, 也须预先规定行动, 才能比较完整策略偏离。但 Nash 条件不唯一规定零概率信息集上的信念; 讨论每处的序贯理性还需额外条件。

16.1.4 完整策略与行为策略

三张牌中, 第 1 方的完整纯策略按“高牌时行动、低牌时行动”有 $(P, P), (B, P), (P, B), (B, B)$ 四种, 第 2 方有 F, C 两种。开局随机抽一份完整计划是一种实现方式; 另一种是在真正到达信息集时才抽行动, 称为行为策略, 也就是把随机选择写在每个可辨认的决策位置上。

定义 16.7 行为策略 参与者 i 的行为策略 (behavior strategy) $\sigma_i(a | I)$ 在每个信息集 $I \in \mathcal{I}_i$ 上分别给出 $A(I)$ 上的概率分布; 同一信息集中的所有历史必须使用同一分布。

三张牌例子可写成三个数:

$$b_H = \sigma_1(B | I_H), \quad b_L = \sigma_1(B | I_L), \quad c = \sigma_2(C | I_2).$$

战略式中的混合策略是在游戏开始时随机抽取一个完整纯计划; 行为策略则在每个信息集到达时随机选择。二者在一般情形下并不等价。若参与者会忘记自己早先知道的牌或采取的行动, 开局抽取的同一个随机计划可以在多个时刻制造相关性, 而独立的局部随机化未必能复制这种相关性。

定义 16.8 完全回忆 完全回忆 (perfect recall) 要求参与者在同一信息集内不能混淆自己过去获得的信息和采取的行动。更具体地说, 任意两个属于同一信息集的历史, 沿途经过的该参与者信息集序列及其本人行动序列必须相同; 这里的过去序列只记录当前节点之前的本人决策。

定理 16.9 Kuhn 实现等价 在有限完全回忆扩展式博弈中, 对任一参与者, 任意混合策略都存在一个行为策略, 使二者面对任意固定的对手与机会策略时诱导相同的终止历史分布; 任意行为策略也存在具有同样性质的混合策略。

证明. 先从混合策略构造行为策略。设 μ_i 是在有限纯策略集合上的分布。完全回忆保证每个信息集 I 都有唯一的本人前缀

$$\rho_i(I) = ((I_1, a_1), \dots, (I_k, a_k)),$$

即到达 I 以前本人依次经过的信息集和采取的行动; 同一 I 中的所有历史共享这条前缀。记 E_I 为纯策略与这条前缀一致的事件。若 $\mu_i(E_I) > 0$, 定义

$$\sigma_i(a | I) = \frac{\mu_i(E_I \cap \{s_i : s_i(I) = a\})}{\mu_i(E_I)},$$

其中 s_i 表示一项完整纯策略, 事件 $s_i(I) = a$ 表示它在当前信息集指定行动 a ; 若分母为零, 就在 $A(I)$ 上任取一个分布。

沿任意终止历史依次考察参与者 i 的行动。链式法则表明, μ_i 抽取的完整计划与这条本人行动序列一致的概率, 等于上述各条件概率的乘积, 也就是行为策略 σ_i 沿该历史贡献的到达概率。对手与机会的路径概率在两种表示下相同, 所以每个终止历史的总概率相同。分母为零的信息集只位于 μ_i 赋予零概率的本人前缀之后, 任意补全都不改变这一结论。

反过来, 给定行为策略 σ_i , 在游戏开始前为每个信息集独立抽取一个行动, 并把全部抽取结果组成纯策略 s_i 。令

$$\mu_i(s_i) = \prod_{I \in \mathcal{I}_i} \sigma_i(s_i(I) | I).$$

对任意终止历史, 把未出现在该历史上的信息集行动求和后都得到因子 1, 剩余因子恰是行为策略沿该历史的行动概率乘积。因此该混合策略面对任意对手与机会策略, 也诱导与原行为策略相同的终止历史分布。 ■

完全回忆不能省略。考虑一位参与者先在 I_1 选择 L 或 R , 随后到达同一个信息集 I_2 , 却忘记了刚才的选择, 并在 I_2 选择 l 或 r 。混合策略可以各以 $1/2$ 抽取完整计划 (L, l) 与 (R, r) , 只产生 Ll 和 Rr 两条历史。任何行为策略若让第一步的 L, R 都以正概率出现, 且让第二步的 l, r 也都以正概率出现, 就还会以正概率产生 Lr 和 Rl ; 若把某个概率设为零, 又无法同时保留前两条历史各 $1/2$ 的概率。因此局部独立随机化不能复现混合计划中的跨时相关性。

牌面例满足完全回忆, 因为每人只行动一次。比如以概率 $2/3$ 抽取 (B, P) 、以概率 $1/3$ 抽取 (B, B) , 等价于 $b_H = 1, b_L = 1/3$ 的行为策略; 此处只验证表示等价, 其价值及最优性将在收益计算和响应条件中分别核对。Kuhn 定理等同的是面对任意固定对手时的终局分布, 不是说两种随机装置内部完全相同。

16.2 策略的多方价值

策略已经给定时, 计算的是这些规则实际产生什么收益, 不需要猜测参与者以后怎样改进。有限行动表按联合概率加权, 历史树按终局概率加权, 两者都使用各方自己的收益。合作分配还需先定义联盟能共同取得的价值; 这个额外模型不能从一人的收益自动推出。

16.2.1 给定策略下的收益计算

16.2.1.1 联合行动下的期望收益

各人独立随机化时, 联合行动 $\mathbf{a}$ 的概率为 $\prod_j \sigma_j(a_j)$, 所以

$$u_i(\sigma) = \sum_{\mathbf{a} \in A_1 \times \cdots \times A_n} \left(\prod_{j=1}^n \sigma_j(a_j) \right) u_i(\mathbf{a}). \quad (16.2)$$

后文仍用 u_i 表示纯行动收益, 以及将纯行动收益按混合概率平均后得到的期望收益; 自变量是行动还是概率分布, 可以区分这两种写法。双人矩阵中, $u_i(\mathbf{x}, \mathbf{y}) = \mathbf{x}^\top \mathbf{U}_i \mathbf{y}$; 零和时只需记录行方的收益:

$$u(\mathbf{x}, \mathbf{y}) = \mathbf{x}^\top \mathbf{M} \mathbf{y}. \quad (16.3)$$

若改用相关联合分布 μ , 应计算

$$u_i(\mu) = \sum_{\mathbf{a}} \mu(\mathbf{a}) u_i(\mathbf{a}),$$

不能把 μ 擅自换成边缘概率的乘积。

匹配硬币的行方收益矩阵为

$$\mathbf{M}_{\text{mp}} = \begin{pmatrix} 1 & -1 \\ -1 & 1 \end{pmatrix}.$$

按四个联合行动的概率加权, 得到混合收益

$$\begin{aligned} u_1(p, q) &= pq + (1-p)(1-q) \\ &\quad - p(1-q) - (1-p)q \\ &= (2p-1)(2q-1). \end{aligned}$$

给定 q , 纯行动 H, T 的收益分别为 $2q-1, 1-2q$ 。例如 $p = 3/4, q = 1/4$ 时, 第1方期望收益为 $-1/4$, 第2方为 $1/4$; 双方均匀随机时, 两人的期望收益都是 0。这些数是给定策略的评价, 尚未检查任何人愿不愿意改变。

16.2.1.2 行动历史下的整局价值

历史树中, 一条终局路径可能包含多次行动。要算整局收益, 先把沿途概率相乘, 再按各终局收益求和。这里的路径概率与条件续局概率即使在当前不会到达的节点, 也可由策略本身计算, 不必对零概率事件作除法。给定联合行为策略 σ , 历史

$$h = (a_1, \dots, a_k)$$

的到达概率 (reach probability) 是沿路径各次行动概率之积。把机会也看作固定策略, 可以写成

$$\pi^\sigma(h) = \pi_i^\sigma(h) \pi_{-i}^\sigma(h), \quad (16.4)$$

其中 $\pi_i^\sigma(h)$ 只乘参与者 i 在路径上的行动概率, $\pi_{-i}^\sigma(h)$ 则乘其他参与者与机会的概率。这个分解不会声称两部分随机变量独立; 它只是把同一条路径上的乘积按行动者归组。

从历史 h 继续到终止历史 z 的条件路径概率记为 $\pi^\sigma(h, z)$ 。

更明确地, 若 h_t 是第 t 步前的历史, 机会贡献为 $\pi_c(h) = \prod_{t: P(h_t)=c} \sigma_c(a_t | h_t)$, 本人贡献为 $\pi_i^\sigma(h) = \prod_{t: P(h_t)=i} \sigma_i(a_t | I(h_t))$; 空积为 1, 而 $\pi_{-i}^\sigma(h) = \pi_c(h) \prod_{j \neq i} \pi_j^\sigma(h)$ 。因此整局价值为

$$u_i(\sigma) = \sum_{z \in Z} \pi^\sigma(z) u_i(z). \quad (16.5)$$

若收益由局内阶段收益累计而来, 可先对每条路径求累计收益再取期望; 这与第 15.4.2 节的续局价值使用同一求和原则, 只是现在路径概率由多方共同决定。

三张牌的六类终局概率可以直接核对：

z	$\pi^\sigma(z)$	$u_1(z)$
(H, P)	$(1 - b_H)/2$	0
(L, P)	$(1 - b_L)/2$	0
(H, B, F)	$b_H(1 - c)/2$	1
(L, B, F)	$b_L(1 - c)/2$	1
(H, B, C)	$b_H c/2$	2
(L, B, C)	$b_L c/2$	-2

它们的概率之和为 1，从而

$$u_1(b_H, b_L, c) = \frac{1}{2}b_H(1 + c) + \frac{1}{2}b_L(1 - 3c), \quad u_2 = -u_1. \quad (16.6)$$

例如全部取 $1/2$ 时，两项分别为 $3/8$ 与 $-1/8$ ，整局收益为 $1/4$ 。在 $(b_H, b_L, c) = (1, 1/3, 1/3)$ 下，整局收益为 $2/3$ ，发生质询的概率为 $(b_H + b_L)/2 = 2/3$ 。给定已经质询，Bayes 公式给出高、低牌概率为 $3/4, 1/4$ ；因此此条件下第 2 方应对或退让的收益均为 -1 。条件收益不是事前收益：后者还需乘上质询概率，放弃路径则贡献零。

把第 1 方四个完整计划分别代入式 (16.6)，并按 F, C 排列列方行动，就得到同一个扩展式博弈的战略式收益矩阵：

$$\mathbf{M} = \begin{pmatrix} 0 & 0 \\ 1/2 & 1 \\ 1/2 & -1 \\ 1 & 0 \end{pmatrix}. \quad (16.7)$$

例如，计划 (B, P) 只在拿到高牌时质询。对方退让时，收益以一半概率为 1、一半概率为 0，故矩阵元素为 $1/2$ ；对方应对时，相应期望为 1。

该矩阵已经对机会发牌取过期望，不能在后续矩阵运算中再乘一次 $1/2$ 。在信息集上比较局部学习信号时，还会有意去掉本人的到达概率；第 16.5.3.1 节将说明这为何不同于条件期望。

16.2.2 对抗与共同收益的价值关系

同一行动空间上可以有不同的利益关系。一般和博弈 (general-sum game) 允许各人收益独立规定；共同收益模型则让所有人使用同一个收益函数。下表固定双方行动 L, R ，只改变收益规则，各格均按第 1 方、第 2 方排列。

一般和行从 (R, R) 换成 (L, L) 能使双方收益由 1 增至 2，称为 Pareto 改进：所有人都不变差且至少一人变好。Pareto 最优 (Pareto optimal) 表示在所声明的可行方案集合内，不存在这样的改进。它比较共同改变后的收益，

收益关系	(L, L)	(L, R)	(R, L)	(R, R)
零和匹配	$(1, -1)$	$(-1, 1)$	$(-1, 1)$	$(1, -1)$
一般和选择	$(2, 2)$	$(0, 3)$	$(3, 0)$	$(1, 1)$
共同协调	$(2, 2)$	$(0, 0)$	$(0, 0)$	$(2, 2)$

表 16.2 同一联合行动集合上的三种教学收益。零和行中一人的增加必伴随另一人的减少；一般和行同时包含共同改善与利益冲突；共同协调行的两人收益逐格相同。表中收益仅用于说明模型关系，不表示参与者已经选定了某种行动。

不是固定对方时一人的改动；下一节的均衡条件将体现这一区别。在共同协调行，双方独立均匀抽样各得期望收益 1，共同建议只抽取 $(L, L), (R, R)$ 且各占一半时各得 2。边缘概率相同，收益却不相同。

温度模型也需要保留这项区别。只看一步并固定当前状态 x ，令

$$J_i(u_1, u_2; x) = (0.8x + u_1 + u_2 - r_i)^2 + \lambda_i u_i^2.$$

这是例 16.3 在 $H = 1$ 时的成本。取 $x = 0, r_1 = r_2 = 2, \lambda_1 = \lambda_2 = 1$ ，若 $(u_1, u_2) = (1, 0)$ ，两人成本分别为 2, 1。改成 $(0.8, 0.8)$ 时，下一时刻温差为 1.6，两人成本均为 $0.4^2 + 0.8^2 = 0.8$ 。共同改善确实可能，但每人是否愿意维持该行动，还要检查固定另一人之后的响应。

16.2.3 合作价值的贡献与分配

16.2.3.1 联盟价值与边际贡献

若参与者决定共享信息或资源，问题转为合作能产生多少额外价值，以及如何分给成员。这里的多方信用分配（multi-party credit allocation）指按联盟贡献确定各人份额 $\psi_i(v)$ ；预算平衡是指所有人的份额恰好分完共同价值，即 $\sum_i \psi_i(v) = v(N)$ 。这与把延迟奖励传回同一参与者的不同时刻不同，后者是强化学习中的时序信用分配。

定义 16.10 可转移效用博弈 可转移效用合作博弈（transferable-utility cooperative game）由参与者集合 N 和联盟价值函数

$$v : 2^N \rightarrow \mathbb{R}, \quad v(\emptyset) = 0$$

组成， N 为非空有限集合。 $v(S)$ 表示联盟 S 独立合作时可取得并能在成员之间转移的总收益。

联盟价值不是从单个模型输出自动得到的。对牌面判断任务，可以把 $v(S)$ 定义为联盟 S 共享信号后，相对于无信号基线减少的最优期望损失；也可以定义为收入、正确判断数或节省的核验成本。不同定义会产生不同

分配。若参与者的收益不能用同一尺度转移，例如一方关心隐私、另一方关心延迟，就需要非可转移效用模型，不能先相加再假装总量可任意拆分。

参与者 i 加入已有联盟 $S \subseteq N \setminus \{i\}$ 的边际贡献为

$$v(S \cup \{i\}) - v(S).$$

这个增加量依赖已经加入的参与者集合 S 。两位牌面观察者可能各自只能提供模糊线索，合在一起却能确定牌面；此时任何一人的“独立贡献”都不能由单独使用他的信号一次决定。

16.2.3.2 基于参与顺序的贡献分配

一个人先加入时贡献小，后加入时可能因已有信息互补而贡献大。对所有加入次序一视同仁，就得到下面的排列平均规则。Shapley 值 (Shapley value) 把参与者在所有随机加入次序中的边际贡献取平均¹。

定义 16.11 Shapley 值 对上述可转移效用博弈、 $n = |N|$ 及参与者 $i \in N$ ，其 Shapley 分配为

$$\phi_i(v) = \sum_{S \subseteq N \setminus \{i\}} \frac{|S|!(n - |S| - 1)!}{n!} [v(S \cup \{i\}) - v(S)]. \quad (16.8)$$

系数是随机排列中恰好由 S 排在 i 之前的概率： S 内部有 $|S|!$ 种次序，其余参与者在 i 之后有 $(n - |S| - 1)!$ 种次序，总排列数为 $n!$ 。

Shapley 值满足四项要求。若两位参与者对所有不含二者的联盟产生相同边际贡献，对称性要求二者分配相同；若参与者对任意联盟的边际贡献都为零，虚设参与者性质要求其分配为零；有效性要求 $\sum_i \phi_i(v) = v(N)$ ；可加性要求对两个价值函数 v, w ，有 $\phi_i(v + w) = \phi_i(v) + \phi_i(w)$ 。

定理 16.12 Shapley 值的公理刻画 在有限可转移效用合作博弈上，同时满足对称性、虚设参与者性质、有效性和可加性的分配规则唯一，并由式 (16.8) 给出。

证明. 先验证式 (16.8) 满足四项性质。它是随机排列下边际贡献的期望。每个排列中，所有参与者的边际贡献沿加入次序望远镜相加为

$$v(N) - v(\emptyset) = v(N),$$

取期望得到有效性。交换两位对称参与者不会改变排列分布或边际贡献分布，得到对称性。虚设参与者的每项边际贡献都为零。边际贡献关于价值函数线性，取期望后得到可加性。

¹ L. S. Shapley, “A Value for n -Person Games”, in: *Contributions to the Theory of Games II*, ed. by H. W. Kuhn, A. W. Tucker, vol. 28, Annals of Mathematics Studies, Princeton University Press, 1953, pp. 307–318

再证唯一性。设 Φ 是任意满足四项公理的分配规则。对每个非空集合 $T \subseteq N$, 定义一致联盟博弈

$$u_T(S) = \begin{cases} 1, & T \subseteq S, \\ 0, & T \not\subseteq S. \end{cases}$$

任意满足 $v(\emptyset) = 0$ 的价值函数都能唯一写成

$$v = \sum_{\emptyset \neq T \subseteq N} c_T u_T, \quad c_T = \sum_{R \subseteq T} (-1)^{|T|-|R|} v(R), \quad (16.9)$$

这是子集格上的包含-排除展开。

还要处理展开式中的任意实系数, 不能只由重复相加得到整数或有理数倍。对任意 $c \in \mathbb{R}$, 在博弈 $c u_T$ 中, T 外的参与者都是虚设参与者, 分配必须为零; T 内参与者彼此对称, 有效性又要求他们的分配和为 c , 所以每人只能得到 $c/|T|$ 。这个结论直接覆盖正、负及无理的 c , 没有预先假设分配规则连续。

式 (16.9) 只有有限项。可加性因此给出

$$\Phi(v) = \sum_{\emptyset \neq T \subseteq N} \Phi(c_T u_T),$$

而每一项已经由上一段唯一确定, 故任意 v 上的分配也唯一。特别地, 对任意 $\alpha \in \mathbb{R}$, 对 αv 使用同一展开便得到 $\Phi(\alpha v) = \alpha \Phi(v)$, 这补出了实齐次性。前半部分已经证明式 (16.8) 满足这些公理, 故它就是唯一规则。 ■

把牌面任务扩展为三位信息提供者。参与者 1 观察牌背纹理, 参与者 2 观察发牌动作, 参与者 3 提供一次较弱的设备校验。以“相对于无信息基线减少的期望损失”为统一收益单位, 假设教学构造的联盟价值为

S	$\emptyset$	$\{1\}$	$\{2\}$	$\{3\}$	$\{1, 2\}$	$\{1, 3\}$	$\{2, 3\}$	$\{1, 2, 3\}$
$v(S)$	0	1	1	0	3	2	2	4

这些数值只用于展示互补贡献: 前两位各自有用, 二者合并额外增益较大; 第三位单独无用, 却能校验已有线索。

对参与者 1, 四类前驱联盟的贡献给出

$$\begin{aligned} \phi_1(v) &= \frac{1}{3}(1-0) + \frac{1}{6}(3-1) + \frac{1}{6}(2-0) + \frac{1}{3}(4-2) \\ &= \frac{5}{3}. \end{aligned}$$

对称性给出 $\phi_2(v) = 5/3$ 。参与者 3 的分配为

$$\begin{aligned}\phi_3(v) &= \frac{1}{3}(0 - 0) + \frac{1}{6}(2 - 1) + \frac{1}{6}(2 - 1) + \frac{1}{3}(4 - 3) \\ &= \frac{2}{3}.\end{aligned}$$

三者之和为 $4 = v(N)$ ，与有效性一致。参与者 3 虽然单独价值为零，却不是虚设参与者，因为加入 $\{1\}$ 、 $\{2\}$ 或 $\{1, 2\}$ 都会增加联盟价值。只按单人表现分配会漏掉这种互补性。

若把价值改成模型预测分数，Shapley 公式仍可计算，但解释也随之改变。它分配的是所定义价值函数相对于基线的差，不自动等于真实因果贡献。特征彼此相关时，“缺少某个特征”的联盟输入怎样构造还需要条件分布、边缘分布或干预语义；这些选择分别回答预测归因与因果效应问题，不能只用同一个 Shapley 名称消除差异。

这个计算只回答怎样按贡献分配已定义的共同价值。成员是否能另组联盟获得更多收益，以及一项分配是否会被接受，属于第 16.3.5 节的偏离检验。

16.3 策略的多方响应与均衡

评价一个策略组合之后，可以固定其他人，询问一人怎样改变才更好。若各人都已作出这种响应，便没有单方改进空间。共同建议改变了偏离者掌握的信息，合作联盟改变了允许共同偏离的人数；每种均衡都必须同时写清这两项条件。

16.3.1 给定其他策略下的最佳响应

对手多质询、少应对，或多加热、少加热，都可能改变本人的最优选择。最佳响应（best response）就是把对手规则当作给定条件，选择本人的最优策略。

定义 16.13 最佳响应 在有限战略式博弈中，给定 σ_{-i} ，参与者 i 的最佳响应集合为

$$\text{BR}_i(\sigma_{-i}) = \arg \max_{\tilde{\sigma}_i \in \Delta(A_i)} u_i(\tilde{\sigma}_i, \sigma_{-i}).$$

双人零和时，行方最大化 $\mathbf{x}^\top \mathbf{M} \mathbf{y}$ ，列方最小化同一个式子。一般和时则各自最大化 $\mathbf{x}^\top \mathbf{U}_i \mathbf{y}$ ，不能再将另一方收益取负。关于本人混合概率的目标是线性的，因此至少一个纯行动达到最大值。若多个纯行动并列最优，其任意混合也最优；最佳响应通常是集合而非唯一行动。

匹配硬币中，两行收益之差为 $4q - 2$ ，所以

$$BR_1(q) = \begin{cases} \{1\}, & q > 1/2, \\ [0, 1], & q = 1/2, \\ \{0\}, & q < 1/2. \end{cases} \quad BR_2(p) = \begin{cases} \{0\}, & p > 1/2, \\ [0, 1], & p = 1/2, \\ \{1\}, & p < 1/2. \end{cases}$$

这里集合中的数是选 H 的概率，不是收益。若对手均匀随机，本人任意混合都是最佳响应；这不等双方可以同时任意混合。

图 16.1 把两方响应放在同一概率平面。在中心位置，整条横线或纵线都对应并列最优的响应；只有两个响应集合相交，才同时满足两方条件。




图 16.1 匹配硬币的最佳响应集合。横轴 p 、纵轴 q 分别是两方选 H 的概率。蓝色实线为行方响应，红色虚线为列方响应；在 $q = 1/2$ 处行方允许全部 p ，在 $p = 1/2$ 处列方允许全部 q ，唯一共同点为 $(1/2, 1/2)$ 。这些线段描述允许的响应，不是实际运行的学习轨迹。

三张牌中，固定应对概率 c 后，高牌质询的收益 $1 + c$ 总大于放弃的 0 ，故 $b_H = 1$ 是最佳选择。低牌质询收益为 $1 - 3c$ ，所以 $c < 1/3$ 时选 $b_L = 1$ ， $c > 1/3$ 时选 $b_L = 0$ ，等于阈值时任意混合都可以。反过来，由式 (16.6) 关于 c 的系数 $(b_H - 3b_L)/2$ ，列方在 $b_H > 3b_L$ 时选 $c = 0$ ，在 $b_H < 3b_L$ 时选 $c = 1$ ，相等时任意 c 都最佳。这里比较的应对概率对两种隐藏牌必须相同，不能越过信息限制。

对温度一步成本，固定 u_j 后严格凸性给出唯一响应。求导并令导数为零：

$$\frac{\partial J_i}{\partial u_i} = 2(0.8x + u_i + u_j - r_i) + 2\lambda_i u_i = 0.$$

于是

$$B_i(u_j; x) = \frac{r_i - 0.8x - u_j}{1 + \lambda_i}. \quad (16.10)$$

在 $x = 0, r_i = 2, \lambda_i = 1$ 时, 对方取 0.8, 本人就愿意改为 0.6。即使 (0.8, 0.8) 使两人成本都低于某个其他方案, 也不能据此称它为相互最佳响应。若要求 $0 \leq u_i \leq 1$, 该二次成本的响应变为将右侧截到 $[0, 1]$; 若还要求下一状态在 $[0, 3]$, 可行区间还依赖对方行动, 须重新核对共同可行性。

16.3.2 相互最佳响应下的 Nash 均衡

16.3.2.1 单方偏离与 Nash 条件

只求一人的响应仍没有决定联合结果。把每人的最佳响应条件同时写下, 就得到 Nash 均衡 (Nash equilibrium): 只要其他人不变, 没有谁能靠单独改策略提高收益。

定义 16.14 Nash 均衡 联合混合策略 σ^* 是 Nash 均衡, 若对每个参与者 i 及每个可实施的替代策略 $\tilde{\sigma}_i$,

$$u_i(\sigma_i^*, \sigma_{-i}^*) \geq u_i(\tilde{\sigma}_i, \sigma_{-i}^*). \quad (16.11)$$

等价地, 各方最大单方改进 $\max_{\tilde{\sigma}_i} u_i(\tilde{\sigma}_i, \sigma_{-i}^*) - u_i(\sigma^*)$ 均为零。每人都采用纯行动时称纯策略均衡, 否则使用混合策略。匹配硬币没有纯均衡: 两面相同则第 2 方愿意改, 不同则第 1 方愿意改; 唯一混合均衡为 $p = q = 1/2$, 收益为零。

三张牌的同时响应要求 $b_H = 1, b_L = 1/3, c = 1/3$ 。零和保证值的证书将在第 16.3.3 节独立核验。温度一步例则解 $2u_1 + u_2 = 2, u_1 + 2u_2 = 2$, 得到唯一解

$$u_1^* = u_2^* = \frac{2}{3}, \quad x_1 = \frac{4}{3}, \quad J_i^* = \frac{8}{9}.$$

双方都不愿独改, 但共同改成 (0.8, 0.8) 可把两人成本降为 $0.8 < 8/9$ 。事实上总成本 $2(u_1 + u_2 - 2)^2 + u_1^2 + u_2^2$ 严格凸, 其梯度为零恰给出 (0.8, 0.8)。Nash 条件不等于总成本最优或 Pareto 最优, 也不比较不同均衡的公平性。这里的 x_1 是从 $x_0 = 0$ 开始的一步结果, 不是闭环系统的稳态温度。

16.3.2.2 响应映射与均衡存在

若每个最佳响应都是唯一且连续的, 就可以把所有人的响应拼成映射

$$B(\sigma) = (BR_1(\sigma_{-1}), \dots, BR_n(\sigma_{-n})),$$

再寻找 $B(\sigma) = \sigma$ 。实际博弈常在收益并列处有多个最佳响应， B 因而不是单值连续函数。强行规定“并列时选编号最小的行动”会造成跳跃，不能直接应用 Brouwer 不动点定理。

存在性论证需要两个不同层次的工具。连续单值映射先借助单纯形边界上的标号和计数证明不动点存在；最佳响应存在并列时，需要保留整组最佳响应，并检查响应集合在取极限和取凸组合时是否仍满足条件。下面保留这两条工具的证明，并在最后逐项核对有限博弈是否满足条件。

引理 16.15 Sperner 引理 把 d 维标准单纯形

$$\Delta^d = \{x \in \mathbb{R}^{d+1} : x \geq 0, 1^\top x = 1\}$$

有限剖分成小单纯形。若每个剖分顶点的标签属于 $\{0, \dots, d\}$ ，并且位于由顶点集合 S 张成的面上的点只能使用 S 中的标签，则同时含有全部 $d+1$ 种标签的小单纯形有奇数个，因而至少存在一个。

证明. 零维单纯形只有一个顶点，结论直接成立。对正维数 d 归纳。 $d=1$ 时，线段两个端点分别只能标 0 与 1。沿剖分顶点从左向右读取标签，每次改变对应一条含有两种标签的小线段；由于起点为 0、终点为 1，改变次数为奇数。

先在 $d=2$ 的三角形中看清高维计数。三条边上的剖分顶点只能使用相应两个端点的标签。例如，顶点 0 与 1 之间的边只能标 0 或 1，一维情形说明这条边上含两种标签的小边有奇数条。计数所有带标签 0,1 的小边与小三角形的邻接：内部小边被两个小三角形共享，贡献两次；大三角形边界上的小边只邻接一个小三角形，而带齐 0,1 的边界小边只能出现在刚才的 0,1 边上。一个全标号小三角形恰有一条 0,1 边，只含标签 0,1 且两种标签都出现的小三角形有两条这样的边，其余小三角形没有。因此邻接总数为奇数迫使全标号小三角形的数量为奇数。一般维证明把“小边”换成余维一的小面，把“小三角形”换成小单纯形。

假设结论对 $d-1$ 维成立。在全部 d 维小单纯形中，计数标签集合恰为 $\{0, \dots, d-1\}$ 的 $(d-1)$ 维面与小单纯形的邻接次数。内部面邻接两个小单纯形，贡献偶数；边界面只邻接一个小单纯形。边界上只有大单纯形的 $x_d = 0$ 面可能出现全部标签 $0, \dots, d-1$ ，因为其他边界面缺少其中某个允许标签。该面继承 Sperner 标号，归纳假设说明其中这类小面有奇数个。因此总邻接次数为奇数。

一个 d 维小单纯形若含有全部标签 $0, \dots, d$ ，恰有一个面带齐 $0, \dots, d-1$ ，即去掉标签 d 顶点所得的面。若它没有标签 d ，却带齐 $0, \dots, d-1$ ，则 $d+1$ 个顶点中恰有一个标签重复，去掉任一重复标签顶点都会得到这样的面，

所以贡献两次；其余小单纯形贡献零次。总邻接次数的奇偶性因而等于全标号小单纯形数目的奇偶性。前者为奇数，后者至少为一。 ■

定理 16.16 Brouwer 不动点定理 若 $K \subseteq \mathbb{R}^d$ 非空、紧且凸，则每个连续映射 $f: K \rightarrow K$ 至少有一个不动点。

证明. 先令 $K = \Delta^d$. 取网格直径趋于零的一列单纯形剖分。若某个剖分顶点 $\mathbf{x}$ 已经满足 $f(\mathbf{x}) = \mathbf{x}$ ，结论成立；否则因为 $\sum_j x_j = \sum_j f_j(\mathbf{x}) = 1$ ，至少存在一个坐标 j 满足 $x_j > f_j(\mathbf{x})$ ，任选这样的 j 作为标签。若 $x_j = 0$ ，这个严格不等式不可能成立，所以边界标号满足引理 16.15 的条件。

每个剖分因而都有一个全标号小单纯形。对第 k 次剖分，记其中标签为 j 的顶点为 $\mathbf{x}_{k,j}$ 。由紧性可取子列，使 $\mathbf{x}_{k,0} \rightarrow \mathbf{x}^*$ ；小单纯形直径趋于零，所以每个 $\mathbf{x}_{k,j}$ 都趋于同一个 $\mathbf{x}^*$ 。标签定义和连续性给出

$$x_j^* \geq f_j(\mathbf{x}^*), \quad j = 0, \dots, d.$$

两边坐标和都为 1，故所有不等式只能同时取等号， $f(\mathbf{x}^*) = \mathbf{x}^*$ 。

对一般的非空紧凸集 K ，取一个包含 K 的有限维单纯形 S ，并记 $\Pi_K: S \rightarrow K$ 为到闭凸集 K 的欧氏投影。映射 $g = f \circ \Pi_K: S \rightarrow K \subseteq S$ 连续，前一部分给出 $\mathbf{x}^* = g(\mathbf{x}^*)$ 。右侧属于 K ，所以 $\mathbf{x}^* \in K$ 且 $\Pi_K(\mathbf{x}^*) = \mathbf{x}^*$ ，进而 $f(\mathbf{x}^*) = \mathbf{x}^*$ 。 ■

在区间上，这个结论退化为对 $f(x) - x$ 使用介值性质；高维中没有统一的“左右端点”，Sperner 引理用边界相容标号和奇偶计数补上了这一步。Brouwer 只保证不动点存在，不要求映射压缩，因此既不保证不动点唯一，也不保证反复应用 f 会收敛。需要的替代对象保留全部并列响应，不强制挑选其中一个。与单值连续性相应的条件，要求附近输入的响应不能突然出现远离当前响应集合的新值。

定义 16.17 集合值映射与上半连续性 设 $K \subseteq \mathbb{R}^d$ 非空且紧。集合值映射 (correspondence) $F: K \rightrightarrows K$ 给每个 $x \in K$ 指定集合 $F(x) \subseteq K$ ；本节要求各值非空。若对每个 $x \in K$ 及包含 $F(x)$ 的相对开集 $O \subseteq K$ ，都有 x 的相对邻域 U ，使 $F(z) \subseteq O$ 对所有 $z \in U$ 成立，则称 F 上半连续 (upper hemicontinuous)。

在当前紧域、紧值的情形，一个便于使用的等价判据是闭图性质：

$$x_k \rightarrow x, \quad y_k \rightarrow y, \quad y_k \in F(x_k) \implies y \in F(x).$$

闭图判据适用于后面的有限博弈，因为定义域和值域都位于有限维紧集。

这个等价关系也可以直接核对。若闭图成立而上半连续失败，就有包含 $F(x)$ 的相对开集 O ，以及 $x_k \rightarrow x$ 、 $y_k \in F(x_k) \setminus O$ 。紧性给出 y_k 的收敛子列，其极限仍在闭集 $K \setminus O$ ，闭图却要求极限在 $F(x) \subset O$ ，矛盾。反过来，设上半连续且各值紧，若图中的点 $(x_k, y_k) \rightarrow (x, y)$ 而 $y \notin F(x)$ ，紧值与 y 的距离为正。可取包含 $F(x)$ 且与 y 的某邻域不交的相对开集；上半连续迫使最终的 y_k 留在前者，收敛却迫使它们进入后者，再次矛盾。

例如，对手以概率 q 选择左列，而某参与者的两个行动收益分别为 q 和 $1 - q$ 时，其最佳响应对应为

$$\text{BR}(q) = \begin{cases} \{\text{左}\}, & q > 1/2, \\ \Delta(\{\text{左}, \text{右}\}), & q = 1/2, \\ \{\text{右}\}, & q < 1/2. \end{cases}$$

在 $q = 1/2$ 强行挑一个行动会造成单值选择跳跃；保留整段混合策略后，对应的值仍非空、紧且凸，并且极限不会跳出图。这正是 Kakutani 定理保留并列响应的方式。闭图控制极限，凸值允许在网格上混合相邻选择。二者配合，才可以把连续映射的存在工具扩展到集合值响应，而不是对某个不连续的并列选择直接迭代。下面使用的多值映射不动点结论源于 Kakutani 定理²。

²S. Kakutani, *A Generalization of Brouwer's Fixed Point Theorem* In *Duke Mathematical Journal*, 1941, vol. 8, no. 3, pp. 457–459

定理 16.18 Kakutani 不动点定理 设 $K \subseteq \mathbb{R}^d$ 非空、紧且凸。若 $F : K \rightrightarrows K$ 上半连续，并且每个 $F(x)$ 都非空、紧且凸，则存在 $x^* \in K$ 满足 $x^* \in F(x^*)$ 。

下面用单纯形细分和重心插值，把集合值映射转为 Brouwer 定理能够处理的连续映射。

引理 16.19 单纯形上的连续近似选择 在定理 16.18 的条件下，取一个包含 K 的单纯形 $S \subseteq \mathbb{R}^d$ ，并记到 K 的欧氏投影为 $\Pi_K : S \rightarrow K$ 。对每个 $\varepsilon > 0$ ，存在连续映射 $f_\varepsilon : S \rightarrow K$ ，使每个 $x \in S$ 都有 $x' \in S$ 及 $y \in F(\Pi_K(x'))$ 满足

$$\|x - x'\|_2 + \|f_\varepsilon(x) - y\|_2 < \varepsilon.$$

证明. 对 S 取一系列网格直径趋于零的有限单纯形细分。固定第 k 次细分；对每个网格顶点 $\mathbf{v}$ ，从非空集合 $F(\Pi_K(\mathbf{v}))$ 中任选一点 $\mathbf{y}_{\mathbf{v}}$ 。若 $\mathbf{x}$ 位于顶点为 $\mathbf{v}_0, \dots, \mathbf{v}_d$ 的一个小单纯形内，把它写成重心坐标

$$\mathbf{x} = \sum_{j=0}^d \lambda_j \mathbf{v}_j, \quad \lambda_j \geq 0, \quad \sum_{j=0}^d \lambda_j = 1,$$

并定义

$$f_k(\mathbf{x}) = \sum_{j=0}^d \lambda_j \mathbf{y}_{\mathbf{v}_j}.$$

相邻小单纯形在公共面上使用相同的顶点值, 所以这些仿射片段拼成连续映射。又因 K 凸, 每个 $f_k(\mathbf{x})$ 都属于 K 。

在乘积空间上使用 $\|(\mathbf{x}, \mathbf{y})\| = \|\mathbf{x}\|_2 + \|\mathbf{y}\|_2$ 。下面说明网格变细时, $(\mathbf{x}, f_k(\mathbf{x}))$ 会一致逼近对应

$$\tilde{F}(\mathbf{x}) = F(\Pi_K(\mathbf{x}))$$

的图。否则存在 $\varepsilon_0 > 0$ 和点 $\mathbf{x}_k \in S$, 使这些点到 $\text{graph}(\tilde{F})$ 的距离始终至少为 ε_0 。取包含 $\mathbf{x}_k$ 的小单纯形及其顶点 $\mathbf{v}_{k,0}, \dots, \mathbf{v}_{k,d}$ 。由 S 与 K 的紧性, 可沿一个子列令 $\mathbf{x}_k \rightarrow \mathbf{x}$ 、各重心系数收敛, 并令所选的 $\mathbf{y}_{k,j} \in F(\Pi_K(\mathbf{v}_{k,j}))$ 逐项收敛到 $\mathbf{y}_j$ 。网格直径趋于零, 所以每个 $\mathbf{v}_{k,j} \rightarrow \mathbf{x}$; 投影连续和 F 的闭图性质于是给出

$$\mathbf{y}_j \in F(\Pi_K(\mathbf{x})).$$

值集的凸性进一步说明重心极限 $\mathbf{y} = \sum_j \lambda_j \mathbf{y}_j$ 仍属于 $F(\Pi_K(\mathbf{x}))$ 。另一方面, $f_k(\mathbf{x}_k) \rightarrow \mathbf{y}$, 这与到图的距离保持在 ε_0 以上矛盾。因此充分细的网格给出所需 f_ε 。 ■

定理 16.18 的证明. 对 $\varepsilon_k \downarrow 0$, 由引理 16.19 得到连续映射 $f_k : S \rightarrow K \subseteq S$ 。Brouwer 不动点定理说明存在 $x_k \in S$ 使 $x_k = f_k(x_k)$; 由于右侧属于 K , 每个 x_k 其实都在 K 中。 K 紧, 所以某个子列收敛到 $x^* \in K$ 。

近似选择性质给出 $x'_k \in S$ 与 $y_k \in F(\Pi_K(x'_k))$, 使 $\|x_k - x'_k\|_2 + \|x_k - y_k\|_2 \rightarrow 0$ 。因此同一子列上 $\Pi_K(x'_k) \rightarrow x^*$ 且 $y_k \rightarrow x^*$ 。 F 具有闭图, 于是

$$x^* \in F(x^*).$$

细分和重心插值把集合值问题变成连续单值问题, Brouwer 提供近似不动点, 紧性提供收敛子列, 闭图性质再把极限送回 F 。 ■

Nash 的不动点论证给出有限博弈的基本存在性结果³。

³ J. Nash, *Non-Cooperative Games* In *The Annals of Mathematics*, 1951, vol. 54, no. 2, pp. 286–295

定理 16.20 有限博弈存在混合 Nash 均衡 每个参与者和每个行动集都有限的策略式博弈至少存在一个混合策略 Nash 均衡。

证明. 联合混合策略空间

$$K = \prod_{i=1}^n \Delta(A_i)$$

是有限维非空紧凸集。定义联合最佳响应对应

$$F(\sigma) = \prod_{i=1}^n \text{BR}_i(\sigma_{-i}).$$

对固定 σ_{-i} ，收益关于 σ_i 连续，而概率单纯形紧，所以最大值达到， BR_i 非空且紧。收益关于自身混合策略线性，两个最佳响应的凸组合仍达到同一最大值，所以最佳响应值集是凸集。

还需核对闭图。设 $\sigma^{(k)} \rightarrow \sigma$ ，并且 $\tau_i^{(k)} \rightarrow \tau_i$ ，其中 $\tau_i^{(k)} \in \text{BR}_i(\sigma_{-i}^{(k)})$ 。对任意固定替代策略 $\tilde{\sigma}_i$ ，最佳响应性质给出

$$u_i(\tau_i^{(k)}, \sigma_{-i}^{(k)}) \geq u_i(\tilde{\sigma}_i, \sigma_{-i}^{(k)}).$$

有限博弈的期望收益是混合概率的多线性函数，因而连续。令 $k \rightarrow \infty$ ，得到

$$u_i(\tau_i, \sigma_{-i}) \geq u_i(\tilde{\sigma}_i, \sigma_{-i}).$$

这对所有替代策略成立，故 $\tau_i \in \text{BR}_i(\sigma_{-i})$ 。每个分量都具有闭图，有限乘积 F 也上半连续。

定理 16.18 给出 $\sigma^* \in F(\sigma^*)$ 。逐分量展开正是 $\sigma_i^* \in \text{BR}_i(\sigma_{-i}^*)$ ，也就是式 (16.11)。 ■

存在性没有给出唯一性、计算效率或学习动态收敛。即便收益矩阵很小，最佳响应也可能在多个均衡之间切换；在“石头、剪刀、布”一类循环响应中，逐轮选择当前最佳纯行动甚至不会收敛。第 3 章的压缩映射同时给出唯一不动点与迭代收敛，而 Kakutani 只在更弱条件下给出至少一个不动点。这两种结论服务于不同问题。

16.3.3 零和对抗下的保证与均衡

均衡从双方同时响应出发；零和中还可以从一方防御所有对手策略出发。三张牌矩阵的每行最小收益依次为 0, 1/2, -1, 0，每列最大收益均为 1。所以只用纯计划，行方至多保证 1/2，列方却只能将行方收益上界压至 1；不存在纯策略鞍点。允许混合以后，两种保证是否仍有缺口？第 1 位参与者在不知道对方将怎样响应时，希望最大化自己能够保证的最小收益：

$$\underline{v} = \max_{x \in \Delta_m} \min_{y \in \Delta_n} x^\top M y.$$

对固定 x ，第 2 位参与者的目标关于 y 线性，所以最小值在某个纯列达到。因此

$$\min_{y \in \Delta_n} x^\top M y = \min_j (M^\top x)_j.$$

类似地，第 2 位参与者希望把第 1 位参与者的最大可得收益压低到

$$\bar{v} = \min_{\mathbf{y} \in \Delta_n} \max_{\mathbf{x} \in \Delta_m} \mathbf{x}^\top \mathbf{M} \mathbf{y} = \min_{\mathbf{y} \in \Delta_n} \max_i (\mathbf{M} \mathbf{y})_i.$$

对任意 $\mathbf{x}, \mathbf{y}$ ，都有

$$\min_{\tilde{\mathbf{y}}} u(\mathbf{x}, \tilde{\mathbf{y}}) \leq u(\mathbf{x}, \mathbf{y}) \leq \max_{\tilde{\mathbf{x}}} u(\tilde{\mathbf{x}}, \mathbf{y}).$$

分别对左侧取最大、右侧取最小，得到 $\underline{v} \leq \bar{v}$ 。这只是弱极小极大关系。要证明有限零和博弈中两者相等，还需要说明双方约束恰好构成一对线性规划。

定理 16.21 有限零和博弈的极小极大定理 对任意有限收益矩阵 $\mathbf{M}$ ，有

$$\max_{\mathbf{x} \in \Delta_m} \min_{\mathbf{y} \in \Delta_n} \mathbf{x}^\top \mathbf{M} \mathbf{y} = \min_{\mathbf{y} \in \Delta_n} \max_{\mathbf{x} \in \Delta_m} \mathbf{x}^\top \mathbf{M} \mathbf{y}. \quad (16.12)$$

共同数值称为博弈值 v^* 。等式两侧的最优解分别称为双方的极小极大策略。

证明. 引入第 1 位参与者要 guarantees 的收益下界 v 。条件 $(\mathbf{M}^\top \mathbf{x})_j \geq v$ 对每一列成立，恰好表示任何纯列都不能把收益压到 v 以下。第 1 位参与者的问题因此是

$$\begin{aligned} \max_{\mathbf{x}, v} \quad & v \\ \text{s.t.} \quad & \mathbf{M}^\top \mathbf{x} \geq v \mathbf{1}, \\ & \mathbf{1}^\top \mathbf{x} = 1, \quad \mathbf{x} \geq \mathbf{0}. \end{aligned} \quad (16.13)$$

它的最优值正是 $\underline{v}$ 。为第一组不等式引入非负乘子 $\mathbf{y} \geq \mathbf{0}$ ，为概率归一化引入自由乘子 w 。把最大化问题写成上界形式后，其拉格朗日函数可整理为

$$\mathcal{L}(\mathbf{x}, v; \mathbf{y}, w) = v + \mathbf{y}^\top (\mathbf{M}^\top \mathbf{x} - v \mathbf{1}) + w(1 - \mathbf{1}^\top \mathbf{x}).$$

若对自由变量 v 取上确界仍为有限值，必须有 $\mathbf{1}^\top \mathbf{y} = 1$ 。若对 $\mathbf{x} \geq \mathbf{0}$ 取上确界仍为有限值，还必须有

$$\mathbf{M} \mathbf{y} \leq w \mathbf{1}.$$

满足这些条件时，上确界等于 w 。于是对偶问题为

$$\begin{aligned} \min_{\mathbf{y}, w} \quad & w \\ \text{s.t.} \quad & \mathbf{M} \mathbf{y} \leq w \mathbf{1}, \\ & \mathbf{1}^\top \mathbf{y} = 1, \quad \mathbf{y} \geq \mathbf{0}. \end{aligned} \quad (16.14)$$

它要求每个纯行的收益都不超过 w ，所以最优值正是 $\bar{v}$ 。两个单纯形都非空且紧，目标连续，因此式 (16.13) 与 (16.14) 都有有限最优解。第 4.28 号定理给出原对偶最优值相等，即 $\underline{v} = \bar{v} = v^*$ 。■

这个证明不只是交换了 $\max$ 与 $\min$ 。概率归一化把乘子变成对方的混合策略，逐行动收益约束把对偶可行性变成“没有纯行动能突破当前上界”。强对偶定理证明双方能够保证的下界与上界相等，从而得到同一个博弈值。

若 $\mathbf{x}^*$ 与 $\mathbf{y}^*$ 分别是两侧最优策略，则对任意 $\mathbf{x} \in \Delta_m$ 、 $\mathbf{y} \in \Delta_n$,

$$u(\mathbf{x}, \mathbf{y}^*) \leq u(\mathbf{x}^*, \mathbf{y}^*) \leq u(\mathbf{x}^*, \mathbf{y}). \quad (16.15)$$

左侧来自 $\mathbf{y}^*$ 把所有行收益限制在 v^* 以下，右侧来自 $\mathbf{x}^*$ 对所有列保证至少 v^* 。这就是混合策略上的鞍点条件。博弈值由式 (16.12) 唯一确定，但达到该值的策略可以不唯一；把“值唯一”误读成“解唯一”，会遗漏并列最优行动形成的整个最优策略集合。

下面用同一牌面博弈中的具体策略，分别验证行方的收益下界与列方的收益上界。如果这两个界相等，就能确认博弈值，而不只是根据双方收益恰好相等来猜测。对式 (16.7)，令第 1 位参与者在计划 (B, P) 与 (B, B) 上分别放置概率 $2/3$ 与 $1/3$ ，其余计划概率为零：

$$\mathbf{x}^* = (0, 2/3, 0, 1/3)^\top.$$

面对退让列，期望收益为

$$\frac{2}{3} \cdot \frac{1}{2} + \frac{1}{3} \cdot 1 = \frac{2}{3};$$

面对应对列，期望收益为

$$\frac{2}{3} \cdot 1 + \frac{1}{3} \cdot 0 = \frac{2}{3}.$$

所以 $(\mathbf{x}^*, 2/3)$ 是式 (16.13) 的可行解。

再令第 2 位参与者以概率 $2/3$ 退让、以概率 $1/3$ 应对：

$$\mathbf{y}^* = (2/3, 1/3)^\top.$$

四个纯计划对它的收益依次为

$$0, \quad \frac{1}{2} \cdot \frac{2}{3} + 1 \cdot \frac{1}{3} = \frac{2}{3}, \quad \frac{1}{2} \cdot \frac{2}{3} - 1 \cdot \frac{1}{3} = 0, \quad \frac{2}{3}.$$

没有一行超过 $2/3$ ，所以 $(\mathbf{y}^*, 2/3)$ 是式 (16.14) 的可行解。弱对偶已经足以说明两者同时最优，博弈值为 $v^* = 2/3$ 。

从牌面条件看, 这个混合计划等价于: 拿到高牌总是质询, 拿到低牌以概率 $1/3$ 质询; 参与者 2 面对质询时以概率 $1/3$ 应对。若只有高牌质询, 对手就会总是应对, 而不会退让。低牌也按适当概率质询以后, 对手看到质询时, 高、低牌的条件概率变成 $3/4, 1/4$, 应对与退让的期望收益恰好相同, 因而可以混合选择。这个解释依赖参与者 2 看不到牌面; 第 16.1.3 节已把该信息限制写进历史树。

极小极大结论依赖零和结构。若退让、应对或交易产生了双方并不相反的成本, 就不能再用一个标量博弈值同时概括双方目标。此时仍可讨论最佳响应, 但需要按一般和博弈分别检查各方是否存在有利可图的偏离。对于无限或连续行动集, 有限维线性规划证明也不再直接适用; 交换极大与极小通常还需要非空紧凸策略集、收益连续以及相应的凸凹结构。

鞍点条件恰是双方的 Nash 条件: 行方不能增加收益, 列方不能降低行方收益。反过来, 任一零和 Nash 均衡也给出这组鞍点不等式, 故其收益等于同一个博弈值。博弈值限制最坏对手下的期望保证, 不表示任一局实现的收益都等于该值。

16.3.4 共同建议下的偏离与均衡

Nash 均衡要求各人的随机化彼此独立。若一个公共装置先抽取联合行动 $\mathbf{A} \sim \mu$, 再分别向参与者发送建议, 建议之间可以相关。关键问题变成: 参与者在看到自己的建议以后, 是否愿意按建议行动。

定义 16.22 粗相关均衡与相关均衡 设 μ 为有限战略式博弈中联合行动集 $\prod_i A_i$ 上的概率分布。分布 μ 是粗相关均衡 (coarse correlated equilibrium, CCE), 若对每个参与者 i 和任意固定行动 a'_i ,

$$\mathbb{E}_{\mathbf{A} \sim \mu}[u_i(\mathbf{A})] \geq \mathbb{E}_{\mathbf{A} \sim \mu}[u_i(a'_i, \mathbf{A}_{-i})]. \quad (16.16)$$

偏离者必须在看到建议之前承诺改用同一个固定行动。若允许他看到建议 A_i 后按映射 $\phi_i(A_i)$ 改动, 则要求

$$\mathbb{E}_{\mathbf{A} \sim \mu}[u_i(\mathbf{A})] \geq \mathbb{E}_{\mathbf{A} \sim \mu}[u_i(\phi_i(A_i), \mathbf{A}_{-i})] \quad (16.17)$$

对所有映射 $\phi_i : A_i \rightarrow A_i$ 成立, 这定义 相关均衡 (correlated equilibrium, CE)。

在有限行动集上, CE 条件等价于对每对 $a_i, a'_i \in A_i$ 要求

$$\sum_{\mathbf{a}_{-i}} \mu(a_i, \mathbf{a}_{-i}) [u_i(a_i, \mathbf{a}_{-i}) - u_i(a'_i, \mathbf{a}_{-i})] \geq 0. \quad (16.18)$$

它把“收到 a_i 建议后改成 a'_i ”的条件收益比较乘上收到该建议的概率，因此 $\mu(A_i = a_i) = 0$ 时无需另外定义条件概率。CCE 则把求和扩到全部 a_i ，对应参与者在看见建议前就承诺使用固定的 a'_i 。这些都是关于 μ 的线性不等式，所以有限博弈的 CE 与 CCE 集合都是凸多面体。

相关均衡排除的偏离更丰富，所以每个 CE 都是 CCE，反向不一定成立。独立乘积分布形式的 Nash 均衡又是 CE 的特例。这个包含关系来自允许偏离的信息和时机，而不是来自三个名称的“强弱等级”。具体地说，固定偏离是映射偏离的特例，所以 CE 条件蕴含 CCE 条件；在 Nash 乘积分布中，对手行动与自己的建议独立，而自身混合策略支持集中的每个行动都是对 σ_{-i} 的最佳响应，故观察建议后改用任何行动都不能提高收益。

一个二行动协调博弈可以显示相关分布与独立随机化的差别。双方都选 L 或都选 R 时各得 2，行动不同时各得 0。独立地以 $1/2$ 选择两项是一个混合 Nash 均衡，每人期望收益为 1。公共装置若以 $1/2$ 推荐 (L, L) 、以 $1/2$ 推荐 (R, R) ，每人期望收益为 2，并且看到任一建议后偏离都会把收益降为 0，所以该分布是 CE。它不是两个边缘分布的乘积，但只是相对于上述独立混合均衡改善共同收益；该博弈的两个纯 Nash 均衡本来也各给双方收益 2，CE 并不保证优于每个 Nash 均衡。第 16.5 节会看到，外部遗憾自然对应 CCE，内部或交换遗憾才对应 CE。

矩阵博弈中的联合分布也需要与各人的边缘分布区分。表 16.3 固定刚才协调博弈的收益和每人边缘概率：两种制度下每人都以 $1/2$ 选择 L ，但一个制度独立抽样，另一个制度共同推荐。收益差来自行动间的相关性，并非某个参与者改变了单独的混合概率。图 16.2 把两种联合概率逐格显示：独立制度仍会把一半质量放在行动不一致的格子里，共同建议则把这部分质量移到对角线。只看两个边缘分布，无法辨认这种差别；相关均衡的偏离检验也必须使用联合分布。

联合行动	独立混合概率	共同推荐概率
(L, L)	$1/4$	$1/2$
(L, R)	$1/4$	0
(R, L)	$1/4$	0
(R, R)	$1/4$	$1/2$
每人的期望收益	1	2

表 16.3 同一边缘分布下的不同联合行动规律。教学协调博弈在相同行动时各得 2，不同时各得 0。右列是相关均衡，左列是独立混合 Nash 均衡；收益比较只针对这两个分布，纯策略协调均衡同样可以达到收益 2。




图 16.2 二行动协调博弈的两个教学联合分布，共用 0 至 0.5 的概率色阶。行为参与者 1 的行动，列为参与者 2 的行动。左图为独立均匀策略，四格质量均为 0.25；右图只推荐 (L, L) 与 (R, R) ，各占 0.5。两者边缘概率均为 $(0.5, 0.5)$ ，但每人期望收益分别为 1 和 2；相关分布并非边缘分布的乘积。

16.3.5 合作分配下的偏离与稳定

收益已经按贡献分配后，还须问成员愿不愿意留下来。这次允许偏离的单位可以是整个联盟，而不只是一位参与者。这里的稳定指没有获利的退出与重组，不是策略更新对扰动的动态稳定。一个有效分配仍可能被某个联盟拒绝。若分配向量为 $\mathbf{x}$ ，并满足

$$\sum_{i \in N} x_i = v(N),$$

但存在联盟 S 使

$$\sum_{i \in S} x_i < v(S),$$

那么该联盟单独合作可取得更多总收益。若希望没有联盟退出，就需要让每个联盟留在当前分配中得到的总收益，至少等于它独立合作能取得的收益。同时，全部份额还要恰好分完共同收益。

定义 16.23 合作博弈的核心 对可转移效用博弈 (N, v) ，其核心 (core) 为分配向量 $\mathbf{x} \in \mathbb{R}^{|N|}$ 的集合，其中 $\sum_{i \in N} x_i = v(N)$ ，并且 $\sum_{i \in S} x_i \geq v(S)$ 对每个 $S \subseteq N$ 成立。

Shapley 值不一定属于核心，核心也可能为空。例如三人多数联盟的教学价值为 $|S| \geq 2$ 时 $v(S) = 1$ ，否则 $v(S) = 0$ 。三人对称，Shapley 值各为 $1/3$ ；任意两人仅分到 $2/3$ ，却能独立取得 1，因此该分配不在核心。更

强地，三个两人联盟的不阻挡条件相加要求 $2 \sum_i x_i \geq 3$ ，有效性却要求 $\sum_i x_i = 1$ ，二者矛盾，所以核心为空。前者由边际贡献平均和四项公理定义，后者由联盟偏离稳定性定义。

当收益不能转移时，应直接保留收益向量 $\mathbf{u}(\mathbf{a}) = (u_1(\mathbf{a}), \dots, u_n(\mathbf{a}))$ 。第 16.2.2 节的 Pareto 条件只排除共同改进，通常形成一整个前沿，并不选择其中哪一点。第 4.6.1 节中的共同下降方向是一阶局部判据，也不能单独决定全局分配。

即使已经找到 Pareto 最优的收益，仍可能有许多分配方案。要从中选择，可以先规定谈判失败时每个人能得到什么，再比较合作给每个人增加了多少收益。下面的协商规则最大化这些增益的乘积；任何人只得到退出收益时，乘积就为零。

定义 16.24 Nash 乘积协商解 给定分歧点 $\mathbf{d} \in \mathbb{R}^n$ 和可行收益集合 $U \subseteq \mathbb{R}^n$ ，若下式的最大值达到，Nash 协商解 (Nash bargaining solution) 在参与者都不低于分歧收益的区域中选择

$$\max_{\mathbf{u} \in U, \mathbf{u} \geq \mathbf{d}} \prod_{i=1}^n (u_i - d_i), \quad (16.19)$$

其中向量不等式逐坐标理解，称达到最大值的收益向量为协商解。

分歧点表示谈判失败时每人的收益，因而乘积比较的是相对于退出结果的增益，而不是原始收益本身。

定理 16.25 Nash 乘积的存在、唯一性与 Pareto 性质 设 U 非空、紧且凸，并存在 $\hat{\mathbf{u}} \in U$ 满足 $\hat{\mathbf{u}} > \mathbf{d}$ 。则式 (16.19) 存在唯一的最优收益向量 $\mathbf{u}^* > \mathbf{d}$ ，且 $\mathbf{u}^*$ 是 Pareto 最优的。若每位参与者的效用与分歧收益同时作正仿射变换 $u'_i = a_i u_i + b_i$ 、 $d'_i = a_i d_i + b_i$ ，其中 $a_i > 0$ ，变换后的解正是 $\mathbf{u}^{*'} = (a_i u_i^* + b_i)_{i=1}^n$ 。

证明. 个体可接受集合

$$K = U \cap \{\mathbf{u} : \mathbf{u} \geq \mathbf{d}\}$$

非空且紧，乘积目标连续，所以最大值能够达到。严格可行点 $\hat{\mathbf{u}}$ 的乘积为正，而任何至少一个坐标等于相应 d_i 的点乘积为零，因此任一最优解都严格满足 $\mathbf{u} > \mathbf{d}$ 。在这个正增益区域，最大化乘积等价于最大化

$$F(\mathbf{u}) = \sum_{i=1}^n \log(u_i - d_i).$$

每个对数项在其坐标上严格凹，故 F 在正增益区域严格凹。若有两个不同最优点，凸性保证它们的中点仍在 U 内，严格凹性却使中点目标严格大于两端，产生矛盾。因此最优收益向量唯一。

若存在 $\tilde{u} \in U$ 使 $\tilde{u} \geq u^*$ 且至少一个坐标严格更大，则所有增益保持为正，乘积严格增加，与最优性矛盾，所以 u^* 是 Pareto 最优的。正仿射变换后，每个增益变为 $u'_i - d'_i = a_i(u_i - d_i)$ ，整个乘积只乘上与候选点无关的正常数 $\prod_i a_i$ 。可行收益集合与最优点按同一坐标变换对应，因而最优选择不改变。 ■

例如，两位参与者的可行收益满足

$$U = \{(u_1, u_2) : u_1 \geq 0, u_2 \geq 0, u_1 + u_2 \leq 6\}, \quad d = (1, 1).$$

任何最优点都在边界 $u_1 + u_2 = 6$ 上，否则还能同时增加收益。令 $x = u_1 - 1$ ，则 $u_2 - 1 = 4 - x$ ，Nash 乘积为

$$x(4 - x) = 4 - (x - 2)^2,$$

故唯一解为 $(u_1^*, u_2^*) = (3, 3)$ 。若只把分歧点改为 $(0, 1)$ ，边界上的乘积变为 $u_1(5 - u_1)$ ，解随之变成 $(5/2, 7/2)$ 。这个算例说明，协商解的“公平”相对于明确的退出收益而言，并不是脱离分歧点的绝对均分。

图 16.3 将两个分歧点与对应最优收益画在同一可行区域中。两次最优点都落在同一 Pareto 边界上，但分歧点改变后，乘积是在另一组增益坐标中计算，因此最优位置也改变。唯一性来自固定可行域和固定分歧点下的严格凹目标，不表示所有协商制度都应该选同一个收益向量。

没有共同严格正增益时，对数证明不适用，乘积还可能在多个零增益点同时达到最大；若 U 非凸，严格凹性也不能排除不同连通部分上的多个最优点。改变分歧点会改变解，收益若作一般非线性变换，乘积比较同样会改变。这个“协商解”与非合作博弈中的“Nash 均衡”共享提出者姓名，却解决不同问题。

至此，单方策略偏离、依建议改动和联盟退出都有了各自的比较条件。这些条件检验一个候选结果是否会被拒绝，却没有给出参与者从初始选择走向该结果的过程。要研究调整以后会不会回到附近、长期会不会停下来，还需要明确下一轮怎样更新。

16.4 策略的多方演化与稳定

同一个博弈可以配上不同的调整过程。双方可以同时回应上一轮，也可以轮流回应对方刚作出的选择；可以每次求精确最优，也可以只沿当前收益




图 16.3 两方协商的教学可行域 $u_1, u_2 \geq 0$ 、 $u_1 + u_2 \leq 6$ ，两图坐标一致。蓝点为分歧收益，红点为相对该分歧点的 Nash 乘积最优解。左图 $d = (1, 1)$ 得到 $(3, 3)$ ，右图 $d = (0, 1)$ 得到 $(2.5, 3.5)$ ；灰色虚线给出个体可接受的下界。可行总收益没有变化，变化的是退出时可得到的收益。

增加的方向移动一小步。这些过程共享收益函数，却不共享轨迹。因而必须先写出更新，才能讨论均衡附近的扰动或长期极限。

16.4.1 更新规则与策略序列

用 t 表示一局内的物理时间，用 $k = 0, 1, \dots$ 表示策略更新轮次。第 k 轮的联合策略为 $\sigma^{(k)}$ ，该轮温度轨迹若需同时标明两种索引，可写成 $x_t^{(k)}$ 。本节比较相同初态、收益和信息条件下的更新；若每轮初态也变化，就须把它纳入更新输入，不能直接套用下面的固定映射。一般形式为

$$\sigma^{(k+1)} = F_k(\sigma^{(k)}, \mathcal{H}^{(k)}, \xi^{(k)}),$$

其中 $\mathcal{H}^{(k)}$ 是更新时可用的历史信息， $\xi^{(k)}$ 包括抽样或估计噪声。即使局内策略采用随机行动，精确期望收益下的跨轮更新仍可能是确定的。若使用累计遗憾、历史平均或动量，当前策略本身不足以决定下一步，须把这些内部量一并放进动态系统的状态。下面先研究不显含 k 、无噪声的映射。

两方的同时最佳响应使用同一个旧组合：

$$\sigma_1^{(k+1)} \in \text{BR}_1(\sigma_2^{(k)}), \quad \sigma_2^{(k+1)} \in \text{BR}_2(\sigma_1^{(k)}). \quad (16.20)$$

若有并列最优，这只是集合值规则，还须声明怎样选择响应。交替更新把一轮定义为两次依次调整：

$$\sigma_1^{(k+1)} \in \text{BR}_1(\sigma_2^{(k)}), \quad \sigma_2^{(k+1)} \in \text{BR}_2(\sigma_1^{(k+1)}). \quad (16.21)$$

第二方使用新信息，所以两式不是同一个联合映射。实际异步系统若使用延迟观测，还要把延迟写出来。

精确响应可能代价很高。若第 i 方策略由 $\theta_i \in C_i$ 参数化、 C_i 非空闭凸，且收益对该参数可微，可采用

$$\theta_i^{(k+1)} = \Pi_{C_i} \left(\theta_i^{(k)} + \eta_i^{(k)} \nabla_{\theta_i} u_i(\theta^{(k)}) \right). \quad (16.22)$$

这是收益梯度上升；若写成本 $J_i = -u_i$ ，符号改为下降。概率单纯形上的投影保持非负与归一化，但不会自动使对方收益改善，也不保证联合映射收缩。第 16.5.2 节将在凸损失、梯度界和明确反馈条件下证明它的累计保证。用估计梯度替代真梯度时，估计何时形成、是否条件无偏、方差是否受控都是额外假设，不包含在上式的确定性分析中。

两方加热的一步模型使更新次序可以直接计算。固定 $x = 0, r_1 = r_2 = 2, \lambda_1 = \lambda_2 = 1$ ，把每轮重新选择的一步输入写成 $\mathbf{u}^{(k)} = (u_1^{(k)}, u_2^{(k)})^\top$ ，而非局内输入 $u_{i,t}$ 。由第 16.3.1 节的响应公式，

$$B_1(u_2) = 1 - \frac{1}{2}u_2, \quad B_2(u_1) = 1 - \frac{1}{2}u_1.$$

同时更新从 $(0,0)$ 出发依次得到

$$(0,0), \quad (1,1), \quad (1/2, 1/2), \quad (3/4, 3/4), \dots;$$

交替更新从同一点出发，一轮结束时则依次为

$$(0,0), \quad (1, 1/2), \quad (3/4, 5/8), \quad (11/16, 21/32), \dots.$$

从这几步看，两种更新都在接近 $(2/3, 2/3)$ ，但不能凭前几个数确认收敛；下面给出误差递推。

16.4.2 均衡邻域内的扰动与稳定

对确定的联合映射 F ，先检查候选均衡 θ^* 是否满足 $F(\theta^*) = \theta^*$ 。精确最佳响应若在均衡处选择当前策略，这个条件成立；若任意打破并列最优，所选映射却可能把均衡点移走。投影梯度的不动点只给出各方收益在局部不能沿可行方向增加的一阶条件，只有各方收益关于自身策略凹等条件成立时，才足以推出最佳响应。因此更新不动点与 Nash 均衡不能无条件等同。

在此前提下，稳定问的是初始微小偏差会不会一直小，渐近稳定还要求偏差最终趋零。第 13 章的定义现在应用于策略，而不是房间温度。在内点的局部坐标中，若 F 连续可微，令 $\mathbf{e}^{(k)} = \theta^{(k)} - \theta^*$ ，则

$$\mathbf{e}^{(k+1)} = J_F(\theta^*)\mathbf{e}^{(k)} + o(\|\mathbf{e}^{(k)}\|).$$

若谱半径 $\rho(\mathbf{J}_F(\theta^*)) < 1$, 可选一个等价向量范数, 使该矩阵的诱导范数小于 1。由导数连续性, 足够小邻域内的映射仍严格收缩; 取以不动点为中心的更小闭球便得到不变邻域和几何衰减。因此这是局部渐近稳定的充分条件。若存在模大于 1 的特征值, 光滑离散系统的线性化不稳定判据适用; 若有模等于 1 的特征值, 一阶展开本身不作决定, 须检查高阶项或其他不变量。谱半径小于 1 也不要求欧氏距离每一步都下降, 非正规矩阵可以先出现瞬态增长。

单纯形上的内点可先去掉一个由归一化决定的坐标, 在线性切空间中应用这一判断。边界处投影可能不可微; 并列最佳响应可能发生跳变, 集合值响应甚至没有普通 Jacobian。此时应直接验证距离不等式、可行方向或相应集合值条件, 不能把内点判据强行套在边界上。

对加热例, 令 $\mathbf{e}^{(k)} = \mathbf{u}^{(k)} - (2/3, 2/3)^\top$ 。同时响应恰好满足

$$\mathbf{e}^{(k+1)} = \begin{pmatrix} 0 & -1/2 \\ -1/2 & 0 \end{pmatrix} \mathbf{e}^{(k)}. \quad (16.23)$$

特征值为 $1/2, -1/2$, 且每轮欧氏误差恰好缩为一半。交替响应给出

$$\mathbf{e}^{(k+1)} = \begin{pmatrix} 0 & -1/2 \\ 0 & 1/4 \end{pmatrix} \mathbf{e}^{(k)},$$

特征值为 $0, 1/4$ 。两个线性递推都对任意初值收敛, 因而此处的结论不只局部成立。它们收敛到的是固定初态的一步 Nash 输入, 不是共同最优输入, 也不意味着下一局温度自动稳定在 2。

同一成本若改用同时梯度下降, 梯度向量为

$$\mathbf{g}(\mathbf{u}) = \begin{pmatrix} 4u_1 + 2u_2 - 4 \\ 2u_1 + 4u_2 - 4 \end{pmatrix}.$$

固定步长 $\eta > 0$ 时, 误差矩阵是 $\mathbf{I} - \eta \begin{pmatrix} 4 & 2 \\ 2 & 4 \end{pmatrix}$, 特征值为 $1 - 6\eta, 1 - 2\eta$ 。所以 $0 < \eta < 1/3$ 保证全局收敛; $\eta = 1/3$ 保留一个不衰减的交替方向, 更大步长会放大该方向。即使每个人的成本关于自身行动严格凸, 也不能省去步长条件。

再与式 (16.1) 比较。固定反馈下的状态稳定条件是 $|0.8 - k_1 - k_2| < 1$, 其中 k_i 为反馈增益; 上述策略更新的条件却由响应矩阵或梯度步长决定。一个按局内时间 t 判断, 一个按学习轮数 k 判断。若把学习与状态演化同时运行, 分析对象须扩成状态与学习内部量的联合系统, 本节两项分开的计算不能替代它。

16.4.3 长期更新的极限与循环

加热例说明特定响应确实收敛，匹配硬币则说明均衡存在不足以保证这一点。以 $(p^{(k)}, q^{(k)})$ 表示两人选 H 的概率。从纯组合 $(1, 1)$ 出发，式 (16.20) 唯一地给出

$$(1, 1) \mapsto (1, 0) \mapsto (0, 0) \mapsto (0, 1) \mapsto (1, 1).$$

每一步都在最佳回应上一轮，联合序列却是四周期。若改成交替响应，则从 $(1, 1)$ 经一轮到 $(1, 0)$ ，再到 $(0, 1)$ ，此后两个组合交替，也不趋向混合均衡。这些轨迹没有涉及并列响应点，因此循环不是由模糊的择优约定造成的。

梯度小步也不能普遍消除对抗导致的旋转。在概率正方形的内部，对收益 $u_1 = (2p - 1)(2q - 1)$ 、 $u_2 = -u_1$ 同时上升，令 $a^{(k)} = p^{(k)} - 1/2$ 、 $b^{(k)} = q^{(k)} - 1/2$ ，得到

$$\begin{pmatrix} a^{(k+1)} \\ b^{(k+1)} \end{pmatrix} = \begin{pmatrix} 1 & 4\eta \\ -4\eta & 1 \end{pmatrix} \begin{pmatrix} a^{(k)} \\ b^{(k)} \end{pmatrix}.$$

两个特征值为 $1 \pm 4\eta i$ ，模为 $\sqrt{1 + 16\eta^2} > 1$ 。在投影尚未起作用时，平方半径每轮乘上 $1 + 16\eta^2$ ，所以任何正的固定步长都不能使中心局部吸引。触及边界后的轨迹还取决于投影，不能把内部递推无限延长。若改为连续学习时间 τ 的梯度流 $\dot{a} = 4b$ 、 $\dot{b} = -4a$ ，则 $\frac{d}{d\tau}(a^2 + b^2) = 0$ ，得到闭合圆轨道。这里的 τ 不是局内物理时间 t ，也不是离散轮数 k 。




图 16.4 两个已明确更新规则的教学轨迹。左图为相同初态下双加热器的同时最佳响应，从 $u_1^{(0)} = u_2^{(0)} = 0$ 开始，两条输入曲线重合，误差交替减半并趋向 $2/3$ 。右图红色方形箭头是匹配硬币的离散四周期，蓝色圆是内部连续梯度流从 $(p, q) = (0.8, 0.5)$ 出发的闭轨道，中心黄点是 Nash 均衡。圆与方形对应不同更新，均不是最佳响应对应图中的静态集合。

多方演化还可以不以每个个体显式求梯度为出发点。若大量个体采用有限种行动，收益较高的类型在下一时刻占更大比例，就得到按相对收益调整比例的复制动态 (replicator dynamics)。在一个对称双人群体博弈中，设收益矩阵为 $\mathbf{A}$ ，群体比例 $\mathbf{p}(\tau) \in \Delta_m$ ，类型 a 面对群体的收益为 $(\mathbf{A}\mathbf{p})_a$ ，平均收益为 $\mathbf{p}^\top \mathbf{A}\mathbf{p}$ 。“对称”指交换参与者角色也交换收益，即两方收益矩阵为 $\mathbf{A}, \mathbf{A}^\top$ ，不要求 $\mathbf{A}$ 本身是对称矩阵。连续模型为

$$\dot{p}_a = p_a[(\mathbf{A}\mathbf{p})_a - \mathbf{p}^\top \mathbf{A}\mathbf{p}]. \quad (16.24)$$

各坐标导数之和为零，边界 $p_a = 0$ 上该坐标导数也为零，故单纯形保持不变。正比例类型在静止点必须与群体平均收益相同，但未出现的类型仍可能有更高收益。例如一个纯类型顶点总是静止点，却未必是 Nash 均衡；没有该类型的初始个体且没有变异机制时，复制方程不会凭空引入它。

两方角色不同的匹配硬币应写成两个群体，而不是直接套单群体矩阵。两方复制动态为

$$\dot{p} = 2p(1-p)(2q-1), \quad \dot{q} = -2q(1-q)(2p-1).$$

内部轨迹满足

$$\frac{d}{d\tau} \log[p(1-p)q(1-q)] = 0.$$

除中心外，每个内部水平集是围绕中心的闭曲线，向量场在其上不为零，因而形成周期运动。这再次说明混合 Nash 不必吸引学习轨迹，但此处闭轨道一般不是梯度流的圆。

在对称单群体模型中，另一个问题是少量不同策略进入后能否扩张。

定义 16.26 演化稳定策略 设对称双人博弈中使用策略 $\mathbf{p}$ 对阵 $\mathbf{q}$ 的收益为 $U(\mathbf{p}, \mathbf{q}) = \mathbf{p}^\top \mathbf{A}\mathbf{q}$ 。策略 $\mathbf{p}^*$ 是演化稳定策略 (evolutionarily stable strategy, ESS)，若对每个 $\mathbf{q} \neq \mathbf{p}^*$ ，存在 $\bar{\varepsilon}(\mathbf{q}) > 0$ ，使所有 $0 < \varepsilon < \bar{\varepsilon}(\mathbf{q})$ 都满足

$$U(\mathbf{p}^*, (1-\varepsilon)\mathbf{p}^* + \varepsilon\mathbf{q}) > U(\mathbf{q}, (1-\varepsilon)\mathbf{p}^* + \varepsilon\mathbf{q}).$$

左侧是原群体策略面对少量新策略时的收益，右侧是新策略在同一混合群体中的收益。将两侧之差展开为

$$(1-\varepsilon)[U(\mathbf{p}^*, \mathbf{p}^*) - U(\mathbf{q}, \mathbf{p}^*)] + \varepsilon[U(\mathbf{p}^*, \mathbf{q}) - U(\mathbf{q}, \mathbf{q})]$$

可见，对每个 $\mathbf{q} \neq \mathbf{p}^*$ ，第一个括号必须为正，或在它为零时第二个括号必须为正。这给出可直接计算的等价条件，也说明 ESS 必为对称 Nash 策略：若第一个括号为负，再小的正入侵比例也不能满足定义。

例如 $\mathbf{A} = \begin{pmatrix} 0 & 2 \\ 2 & 0 \end{pmatrix}$, $\mathbf{p}^* = (1/2, 1/2)^\top$ 。对任意 $\mathbf{q} = (q, 1 - q)^\top$,

$$\begin{aligned} U(\mathbf{p}^*, \mathbf{p}^*) &= U(\mathbf{q}, \mathbf{p}^*) = 1, \\ U(\mathbf{p}^*, \mathbf{q}) - U(\mathbf{q}, \mathbf{q}) &= 1 - 4q(1 - q) \\ &= (2q - 1)^2. \end{aligned}$$

因此 $\mathbf{p}^*$ 是 ESS。此例复制动态为 $\dot{p} = 2p(1 - p)(1 - 2p)$: $0 < p < 1/2$ 时比例增加, $1/2 < p < 1$ 时减少, 所有内部初值都趋向 $1/2$; 线性化导数为 -1 , 也证实局部吸引。相反, 两个顶点虽静止, 却可被缺席类型侵入。ESS 检验少量策略入侵, 动态稳定检验指定方程的扰动, Nash 检验单方偏离; 这里同时成立的结论来自具体计算, 不代表三种定义相同, 也不涵盖有限群体随机漂移。

最后须说明“长期结果”指什么。逐轮策略是 $\sigma^{(k)}$, 某个点的收敛是 $\|\sigma^{(k)} - \sigma^*\| \rightarrow 0$; 接近均衡集合仅要求到该集合的距离趋零, 若集合不止一点, 两者不同。有限矩阵策略的时间平均与实际行动经验分布分别为

$$\bar{\sigma}_i^{(K)} = \frac{1}{K} \sum_{k=1}^K \sigma_i^{(k)}, \quad \hat{\mu}^{(K)}(\mathbf{a}) = \frac{1}{K} \sum_{k=1}^K \mathbb{I}\{\mathbf{a}^{(k)} = \mathbf{a}\}.$$

若每轮只计算混合策略而不抽样, 保留轮内独立性的对应联合平均是 $\mu_{\text{mix}}^{(K)} = K^{-1} \sum_k \otimes_i \sigma_i^{(k)}$, 通常不等于 $\otimes_i \bar{\sigma}_i^{(K)}$ 。实际经验分布与这个混合分布平均之间还隔着抽样误差。匹配硬币的四周期每轮策略没有极限, 但每满四轮, 两方平均都为 $(1/2, 1/2)$ 。这只是该轨迹的计算结果, 不能证明任意响应算法都有低遗憾。反过来, 即使已有低遗憾, 也仍须说明它控制的是哪个平均对象。

16.5 策略的多方累积表现

策略没有停下来时, 仍可问整个过程是否持续错过某个更好的固定选择。遗憾把实际收益序列与同一评价序列下的替代策略比较: 固定的是已经记录的对对手策略, 不是假设自己改动以后对手会重新学习。若替代行为还会改变对手的后续响应, 就须另建反事实演化模型; 本节基本遗憾界不比较两套重新运行的学习系统。

16.5.1 固定比较策略下的累计差距

先以损失说明符号, 损失越小越好。在第 K 轮结束后回看, 假设始终使用同一个行动, 它会比实际选择少付出多少损失?

定义 16.27 外部遗憾 设行动集 A 非空且有限。同一参与者在第 k 轮选择 $a^{(k)}$, 面对损失函数 $\ell^{(k)} : A \rightarrow \mathbb{R}$ 。相对于事后最佳固定行动的外部遗憾 (external regret) 为

$$R_{\text{ext}}^{(K)} = \max_{a \in A} \sum_{k=1}^K [\ell^{(k)}(a^{(k)}) - \ell^{(k)}(a)]. \quad (16.25)$$

记 $[z]_+ = \max\{z, 0\}$ 。若 $[R_{\text{ext}}^{(K)}]_+/K \rightarrow 0$, 称该序列无外部遗憾, 即平均每轮损失渐近不高于任何固定行动。这里保留正部, 是因为实际序列可能比所有固定行动都好, 使未经截断的遗憾为负; 定义不要求它从负侧趋于零。比较对象不是每轮先看到损失再重新选择的动态先知; 后者通常能取得更小损失, 要对它给出累计保证, 还需要变化预算或可预测性等条件。

例如两行动 B, P 的损失向量交替为 $(0, 1)$ 、 $(1, 0)$, 共 $2m$ 轮。始终选择 B 的损失为 m , 最佳固定行动的损失也是 m , 外部遗憾为零; 每轮可预知损失的先知却能取得零损失, 差距为 m 。若每轮使用分布 $\mathbf{w}^{(k)}$, 则将实际项改为期望损失 $\langle \mathbf{w}^{(k)}, \boldsymbol{\ell}^{(k)} \rangle$ 。对任何固定混合分布, 累计损失仍是其概率的线性函数, 最小值在某个纯行动达到, 所以固定混合比较并未提高这类线性损失下的最优比较值。但抽样行动的实际遗憾与分布的期望损失遗憾并非同一随机变量。

定义 16.28 内部遗憾 在同一行动损失序列下, 内部遗憾 (internal regret) 允许把每次实际选择 a 的轮次统一替换成另一行动 b , 对应差距为

$$R_{a \rightarrow b}^{(K)} = \sum_{k=1}^K \mathbb{I}\{a^{(k)} = a\} [\ell^{(k)}(a) - \ell^{(k)}(b)].$$

对所有 $(a, b) \in A \times A$ 计算该量, 其最大正部称为内部遗憾。

控制所有这类差距, 表示在知道“原本要选 a ”以后, 也没有持续更好的统一替换。对任意固定 b , 外部比较差距等于 $\sum_a R_{a \rightarrow b}^{(K)}$; 故有限行动下无内部遗憾蕴含无外部遗憾, 反向一般不成立。这些比较分别对应相关均衡中按建议改动和粗相关均衡中的固定偏离。改用收益 $u^{(k)} = -\ell^{(k)}$ 时, 遗憾写成替代收益减实际收益, 正号仍表示偏离有利, 不能把两种约定混用。

16.5.2 基于投影更新的累计保证

若每轮只需沿当前损失的下降方向调整, 怎样控制所有轮次合起来的损失? 关键不是证明每轮都更接近当轮最优点, 而是跟踪到同一个固定比较点的距离。下面的次梯度界采用全信息或可取得真次梯度的反馈。

第4.4.1节的投影不只用于离线优化,也能控制在线累计损失⁴。设 $C \subseteq \mathbb{R}^d$ 为非空闭凸集,直径至多为 $D \geq 0$, 即对任意 $\mathbf{u}, \mathbf{v} \in C$ 都有 $\|\mathbf{u} - \mathbf{v}\|_2 \leq D$ 。给定轮数 $K \geq 1$ 和步长 $\eta > 0$, 第 k 轮在选择 $\mathbf{w}^{(k)} \in C$ 后观察凸损失 $f^{(k)}$, 取次梯度 $\mathbf{g}^{(k)} \in \partial f^{(k)}(\mathbf{w}^{(k)})$, 并假设 $\|\mathbf{g}^{(k)}\|_2 \leq G$, 其中 $G \geq 0$ 。在线投影次梯度更新为

$$\mathbf{w}^{(k+1)} = \Pi_C(\mathbf{w}^{(k)} - \eta \mathbf{g}^{(k)}). \quad (16.26)$$

定理 16.29 在线投影次梯度的外部遗憾 对任意比较点 $\mathbf{w} \in C$, 更新 (16.26) 满足

$$\sum_{k=1}^K (f^{(k)}(\mathbf{w}^{(k)}) - f^{(k)}(\mathbf{w})) \leq \frac{D^2}{2\eta} + \frac{\eta G^2 K}{2}. \quad (16.27)$$

当 $D > 0$ 且 $G > 0$ 时, 取 $\eta = D/(G\sqrt{K})$, 右侧为 $DG\sqrt{K}$ 。若 $D = 0$, 则 C 只有一个点; 若 $G = 0$, 次梯度不等式说明每轮差值都不大于零。两种退化情形的遗憾上界均为零, 无需使用这个步长公式。

证明. 欧氏投影不会增加到任意可行点的距离, 所以

$$\begin{aligned} \|\mathbf{w}^{(k+1)} - \mathbf{w}\|_2^2 &\leq \|\mathbf{w}^{(k)} - \eta \mathbf{g}^{(k)} - \mathbf{w}\|_2^2 \\ &= \|\mathbf{w}^{(k)} - \mathbf{w}\|_2^2 - 2\eta \langle \mathbf{g}^{(k)}, \mathbf{w}^{(k)} - \mathbf{w} \rangle + \eta^2 \|\mathbf{g}^{(k)}\|_2^2. \end{aligned}$$

凸函数的次梯度不等式给出

$$f^{(k)}(\mathbf{w}^{(k)}) - f^{(k)}(\mathbf{w}) \leq \langle \mathbf{g}^{(k)}, \mathbf{w}^{(k)} - \mathbf{w} \rangle.$$

把内积从距离展开式中解出并代入, 得到

$$f^{(k)}(\mathbf{w}^{(k)}) - f^{(k)}(\mathbf{w}) \leq \frac{\|\mathbf{w}^{(k)} - \mathbf{w}\|_2^2 - \|\mathbf{w}^{(k+1)} - \mathbf{w}\|_2^2}{2\eta} + \frac{\eta G^2}{2}.$$

对 k 求和后, 距离平方项望远镜消去, 只剩初始距离上界 D^2 , 得到式 (16.27)。当 $D, G > 0$ 时, 对右侧关于 η 配平即得 $DG\sqrt{K}$; 退化情形按定理后的说明处理。■

这个证明允许损失序列依赖过去行动, 只要当前行动在当前损失揭晓前确定。它给出 $O(\sqrt{K})$ 累计遗憾和 $O(K^{-1/2})$ 平均遗憾, 却没有声称 $\mathbf{w}^{(k)}$ 本身收敛。把低遗憾用于博弈时, 通常得到经验分布或平均策略的结论。

概率单纯形把这个通用更新接回混合策略。设行动集为 $A = \{B, P\}$, 取 $C = \Delta(A)$, 并令第 k 轮两个行动的损失向量为 $\boldsymbol{\ell}^{(k)}$ 。分布 $\mathbf{w} \in C$ 的期望损失

$$f^{(k)}(\mathbf{w}) = \langle \mathbf{w}, \boldsymbol{\ell}^{(k)} \rangle$$

⁴ M. Zinkevich, *Online Convex Programming and Generalized Infinitesimal Gradient Ascent* In Proceedings of the Twentieth International Conference on Machine Learning, 2003, pp. 928–936

是线性函数，次梯度就是 $\ell^{(k)}$ 。若 $\mathbf{w}^{(k)} = (1/2, 1/2)^\top$ 、 $\ell^{(k)} = (0, 1)^\top$ 且 $\eta = 1/2$ ，则

$$\Pi_{\Delta(A)}(\mathbf{w}^{(k)} - \eta \ell^{(k)}) = (3/4, 1/4)^\top.$$

投影把概率从本轮损失较大的 P 移向 B ，同时保持坐标非负且和为 1。定理因而说明混合策略空间上可以构造局部无外部遗憾更新。下面的 CFR 在各信息集采用遗憾匹配，而不是必须采用欧氏投影；这里的通用结果用于建立两类更新共享的无遗憾目标。

这里的 $f^{(k)}$ 可由第 k 轮对手策略产生，损失不必跨轮相同。固定比较点 $\mathbf{w}$ 在整个求和中不变，这是望远镜论证能够直接给出外部遗憾的原因。未知总轮数时，不能直接预设含 K 的固定步长；可另用递减步长或分段重启并重新累计界。本定理只证明所声明的固定时域版本。

若只观察抽中的行动损失，通常无法直接取得完整损失向量。可构造估计量，但须声明探索概率、条件无偏性和二阶矩界；期望界与高概率界也要分别推导。第 10 章的随机评价工具负责这些附加误差，不可把确定性梯度界原样用于任意带噪反馈。

16.5.3 基于局部遗憾的整局保证

在历史树中，完整纯策略的数量可能很大，直接为每个完整纯策略维护概率并逐轮更新，计算代价可能很高。能否只在各信息集比较当前行动，再把局部差距合成整局保证？信息集允许哪些偏离已在第 16.1.3 节确定；剩下的困难是不同位置的到达概率不同，而且改变上游策略会改变下游访问频率。

16.5.3.1 信息集上的反事实收益比较

沿用第 16.2.1.2 节的到达分解 $\pi^\sigma(h) = \pi_i^\sigma(h)\pi_{-i}^\sigma(h)$ ，以及从 ha 继续到终局的路径概率 $\pi^\sigma(ha, z)$ 。若局部差距乘上本人当前策略到达该信息集的概率，一个目前很少访问的位置几乎得不到纠正；将来改变上游行动后，它却可能变得重要。下面暂时去掉自身前缀概率，保留对手与机会权重，这样，无论以后采用哪项完整替代策略，都可以复用这些局部收益差来计算整局改进。

示例 16.30 同一参与者的两层决策 为单独观察自身到达权重，图 16.5 给出没有对手行动和机会分支的小树。参与者 i 在信息集 I_0 选择进入 E 或退出 Q ；退出立即得到 0。进入以后，他在 I_1 再次选择 L 或 R ，收益分别为 1 与 0。记进入概率为 p ，到达 I_1 后选择 L 的概率为 q ，则整局期望收益为 pq 。两个信息集各只含一个历史；参

与者在 I_1 记得自己选择了 E ，因此满足完全回忆。到达 I_1 的本人前缀概率为 p ，对手与机会的到达权重为 1。

若只把第二步改成总选 L ，当前整局收益增加 $p(1-q)$ 。当 $p=0$ 时，这个增量为零，即使 $q < 1$ ，第二步仍有改进余地。完整替代计划却可以同时改成进入并选 L ，取得收益 1。这说明用当前访问概率缩小第二步的学习信号，可能掩盖改变第一步以后才会用到的改进。




图 16.5 同一参与者 i 的两层决策。圆节点是其信息集，方节点中的数值是终局收益。第一步以概率 p 进入，第二步在已进入的条件下以概率 q 选 L ；因此到达收益为 1 的终局需经过两个本人行动，概率为 pq 。本图没有对手或机会节点，是用于区分自身到达概率与局部行动概率的教学构造。

定义 16.31 反事实价值 给定上述联合行为策略及到达权重，参与者 i 在信息集 I 采取行动 $a \in A(I)$ 的反事实价值 (counterfactual value) 定义为

$$v_i^\sigma(I, a) = \sum_{h \in I} \pi_{-i}^\sigma(h) \sum_{z \geq ha} \pi^\sigma(ha, z) u_i(z). \quad (16.28)$$

信息集当前策略的反事实价值为

$$v_i^\sigma(I) = \sum_{a \in A(I)} \sigma_i(a | I) v_i^\sigma(I, a). \quad (16.29)$$

式 (16.28) 把小树中的处理推广到一般信息集：去掉参与者 i 到达 I 以前的本人行动概率，保留对手与机会的到达权重，再按当前续局策略计算各行动的收益。这个量用于比较局部偏离，尚不是当前整局收益，也不是在“已经到达 I ”条件下归一化后的期望。

在例 16.30 中，去掉自身前缀概率 p 以后， $v_i(I_1, L) = 1$ 、 $v_i(I_1, R) = 0$ ，当前局部价值为 $v_i(I_1) = q$ 。选 L 的局部改进量为 $1 - q$ ，因而在 $p = 0$ 时仍

保留信号。它没有声称当前整局收益已经增加了 $1 - q$ ；比较完整替代计划时，还要补回该计划自己到达 I_1 的概率。

在均衡牌面策略下，参与者 2 的信息集包含高牌质询与低牌质询两个节点。对参与者 2 而言，相应反事实到达权重为

$$\frac{1}{2}b_H^* = \frac{1}{2}, \quad \frac{1}{2}b_L^* = \frac{1}{6}.$$

若把它们归一化，得到到达信息集后的信念

$$\mathbb{P}(H | B) = \frac{3}{4}, \quad \mathbb{P}(L | B) = \frac{1}{4}.$$

在这组权重下，参与者 2 选择应对的反事实价值为 $\frac{1}{2}(-2) + \frac{1}{6}(2) = -\frac{2}{3}$ ，退让的反事实价值为 $(\frac{1}{2} + \frac{1}{6})(-1) = -\frac{2}{3}$ 。除以总权重 $2/3$ 后，两项条件期望收益都为 -1 。局部是否偏好一个行动由同一比例缩放保持，但跨信息集求和必须保留原权重。后验概率用于该信息集内的条件决策，反事实价值则保留未归一化权重，以便把不同信息集的局部偏离加回整局收益。两者只差一个到达概率因子，却服务于不同推导。

此处“反事实”不同于第 12 章的因果反事实：前者在既定博弈中去掉本人到达权重，后者固定同一单位的外生背景并替换结构方程。前者不提供因果识别结论。尤其不能先在每个信息集随意归一化，再把不同位置的条件收益直接相加充当整局差距。

前两小节采用损失约定，遗憾写成实际损失减替代损失。扩展式博弈沿用收益函数，下面改用收益约定，把遗憾写成替代收益减当前收益；令损失等于收益的相反数，就能在两种约定之间转换，正遗憾始终表示偏离更有利。

在第 k 轮扩展式博弈中，联合策略记为 $\sigma^{(k)}$ 。参与者 i 在信息集 I 把当前随机行动改成固定行动 a 的即时反事实遗憾为

$$r_i^{(k)}(I, a) = v_i^{\sigma^{(k)}}(I, a) - v_i^{\sigma^{(k)}}(I). \quad (16.30)$$

累计量及其正部最大值记为

$$R_i^{(K)}(I, a) = \sum_{k=1}^K r_i^{(k)}(I, a), \quad R_{i,+}^{(K)}(I) = \max \left\{ 0, \max_{a \in A(I)} R_i^{(K)}(I, a) \right\}.$$

反事实遗憾最小化 (counterfactual regret minimization, CFR) 在每个信息集运行一个局部无遗憾算法⁵。一次完整树更新包含四步：固定本轮联合行为策略并遍历历史树，计算各信息集的反事实行动价值；用式 (16.30) 累计每个行动的遗憾；用局部遗憾匹配生成下一轮策略；同时按本人的到达

⁵ M. Zinkevich, M. Johanson, M. Bowling, C. Piccione, *Regret Minimization in Games with Incomplete Information* In *Advances in Neural Information Processing Systems*, 2007, pp. 1729–1736

概率累计平均策略所需的实现权重。这里的“最小化”是让平均正遗憾趋近于零，不是逐轮直接最小化某个静态目标。

典型的遗憾匹配 (regret matching) 按正累计遗憾选择下一轮行动：

$$\sigma_i^{(k+1)}(a | I) = \begin{cases} \frac{[R_i^{(k)}(I, a)]_+}{\sum_b [R_i^{(k)}(I, b)]_+}, & \sum_b [R_i^{(k)}(I, b)]_+ > 0, \\ \frac{1}{|A(I)|}, & \text{否则.} \end{cases} \quad (16.31)$$

所有 $R_i^{(0)}(I, a)$ 初始化为零，首轮因此使用均匀分布。

若存在 $\Delta_I \geq 0$ ，使对每轮 $k = 1, \dots, K$ 及任意 $a, b \in A(I)$ 都有

$$|v_i^{\sigma^{(k)}}(I, a) - v_i^{\sigma^{(k)}}(I, b)| \leq \Delta_I,$$

则遗憾匹配满足

$$R_{i,+}^{(K)}(I) \leq \Delta_I \sqrt{|A(I)|K}. \quad (16.32)$$

证明可用势函数 $\Phi^{(k)} = \sum_a [R_i^{(k)}(I, a)]_+^2$ ，其中 $\Phi^{(0)} = 0$ 。对任意实数 x, y ，有 $[x + y]_+^2 \leq [x]_+^2 + 2[x]_+ y + y^2$ ；将它用于累计遗憾递推，每轮势函数增量中的交叉项为

$$2 \sum_a [R_i^{(k-1)}(I, a)]_+ r_i^{(k)}(I, a).$$

当正遗憾和非零时，式 (16.31) 使它正比于 $\sum_a \sigma_i^{(k)}(a | I) r_i^{(k)}(I, a) = 0$ ；正遗憾和为零时，交叉项也不为正。平方增量至多 $\sum_a (r_i^{(k)}(I, a))^2 \leq |A(I)| \Delta_I^2$ 。归纳得到 $\Phi^{(K)} \leq K |A(I)| \Delta_I^2$ ，而每个正累计遗憾的平方不超过 $\Phi^{(K)}$ ，于是得到式 (16.32)。

用三张牌博弈核对一次参与者 2 的 CFR 更新。假设当前策略取

$$b_H = b_L = \frac{1}{2}, \quad \sigma_2(C | I_2) = \sigma_2(F | I_2) = \frac{1}{2}.$$

参与者 2 到达高牌质询节点和低牌质询节点的反事实权重都为

$$\frac{1}{2} \cdot \frac{1}{2} = \frac{1}{4}.$$

第一个因子来自机会发牌，第二个因子来自参与者 1 质询。应对 C 时，参与者 2 在高牌和低牌节点的收益分别为 -2 与 2 ，所以

$$v_2(I_2, C) = \frac{1}{4}(-2) + \frac{1}{4}(2) = 0.$$

退让 F 时，参与者 1 在两个节点都得到 1，参与者 2 因而都得到 -1 ，所以

$$v_2(I_2, F) = \frac{1}{4}(-1) + \frac{1}{4}(-1) = -\frac{1}{2}.$$

当前均匀策略的反事实价值为 $-1/4$ ，本轮即时遗憾因此为

$$r_2(I_2, C) = \frac{1}{4}, \quad r_2(I_2, F) = -\frac{1}{4}.$$

若此前累计遗憾为零，遗憾匹配在下一轮把全部概率放到 C 。这个结果只描述一次局部更新；参与者 2 更常应对以后，低牌质询会变得不利，参与者 1 的后续更新又会改变两个节点的权重。因而不能把首轮纯响应当成收敛策略，也不能从这一个数值步骤推出均衡保证。

16.5.3.2 完全回忆下的局部遗憾汇总

局部无遗憾尚未回答完整策略能改善多少。证明须把对手与机会的到达权重留在局部量中，再用同一个替代策略的自身到达概率汇总；完全回忆保证汇总时每条本人决策前缀不含歧义。

整局外部遗憾允许参与者把当前行为策略替换成任意固定行为策略：

$$R_i^{(K)} = \max_{\tilde{\sigma}_i} \sum_{k=1}^K \left[u_i(\tilde{\sigma}_i, \sigma_{-i}^{(k)}) - u_i(\sigma^{(k)}) \right]. \quad (16.33)$$

局部反事实遗憾之所以有用，在于它们能够上界这个看似覆盖整棵树的比较。

例 16.30 可以先展示一次拆分。当前策略为 (p, q) ，完整替代策略为 $(\tilde{p}, \tilde{q})$ 时，

$$\tilde{p}\tilde{q} - pq = (\tilde{p} - p)q + \tilde{p}(\tilde{q} - q). \quad (16.34)$$

第一项只改 I_0 的进入概率，保留当前第二步 q ；第二项再改 I_1 的行动，乘上的却是替代计划的进入概率 $\tilde{p}$ 。第二步的局部改进先去掉当前自身权重 p ，在完整计划比较中再补回 $\tilde{p}$ ，就能同时处理上游和下游都改变的情况。例如 $p = q = 0$ 、 $\tilde{p} = \tilde{q} = 1$ 时，第一项为零，第二项为 1，恰好恢复整局收益的增加。下面把这项拆分沿所有本人信息集重复。

定理 16.32 CFR 的反事实遗憾分解 在有限完全回忆扩展式博弈中，

$$R_i^{(K)} \leq \sum_{I \in \mathcal{I}_i} R_{i,+}^{(K)}(I). \quad (16.35)$$

证明. 固定替代行为策略 $\tilde{\sigma}_i$ 。证明先在一轮中把整局偏离逐层拆开，再对轮次求和。为看清拆分发生在哪里，对 $h \in I$ 定义当前策略在行动 a 后的条件续局收益

$$q_i^{(k)}(h, a) = \sum_{z \geq ha} \pi^{\sigma^{(k)}}(ha, z) u_i(z),$$

并以 $\tilde{q}_i^{(k)}(h, a)$ 表示对手和机会仍采用 $\sigma_{-i}^{(k)}$ ，而参与者 i 从 ha 以后采用 $\tilde{\sigma}_i$ 时的同一数值，即

$$\tilde{q}_i^{(k)}(h, a) = \sum_{z \geq ha} \pi(\tilde{\sigma}_i, \sigma_{-i}^{(k)})(ha, z) u_i(z).$$

当前策略从 h 出发的续局收益为 $q_i^{(k)}(h) = \sum_b \sigma_i^{(k)}(b | I) q_i^{(k)}(h, b)$ 。在替代收益中加上再减去“只在当前行动改用替代分布、以后仍用当前策略”的收益，逐历史得到恒等式

$$\begin{aligned} & \sum_{a \in A(I)} \tilde{\sigma}_i(a | I) \tilde{q}_i^{(k)}(h, a) - q_i^{(k)}(h) \\ &= \sum_{a \in A(I)} \tilde{\sigma}_i(a | I) (q_i^{(k)}(h, a) - q_i^{(k)}(h)) \\ & \quad + \sum_{a \in A(I)} \tilde{\sigma}_i(a | I) (\tilde{q}_i^{(k)}(h, a) - q_i^{(k)}(h, a)). \end{aligned} \quad (16.36)$$

第一项只改变当前信息集的行动，第二项只记录当前行动之后继续偏离的收益。

下面把逐历史恒等式汇总到信息集。记 $\mathcal{C}_i(I, a)$ 为采取 a 以后、在参与者 i 再次行动时首次遇到的本人信息集集合；若在此之前终止，就没有后继信息集。令 $\tilde{v}_i^{(k)}(I)$ 为到达 I 的对手与机会权重仍取 $\pi_{-i}^{\sigma_{-i}^{(k)}}(h)$ ，但从 I 起参与者 i 都采用 $\tilde{\sigma}_i$ 的反事实价值，并记

$$D_i^{(k)}(I) = \tilde{v}_i^{(k)}(I) - v_i^{\sigma_{-i}^{(k)}}(I), \quad L_i^{(k)}(I) = \sum_a \tilde{\sigma}_i(a | I) r_i^{(k)}(I, a).$$

将式 (16.36) 乘以 $\pi_{-i}^{\sigma_{-i}^{(k)}}(h)$ 并对 $h \in I$ 求和，得到信息集偏离收益恒等式

$$D_i^{(k)}(I) = L_i^{(k)}(I) + \sum_{a \in A(I)} \tilde{\sigma}_i(a | I) \sum_{I' \in \mathcal{C}_i(I, a)} D_i^{(k)}(I'). \quad (16.37)$$

这里没有漏掉从 I 到 I' 之间的概率：这段路径上参与者 i 不再行动，对手和机会的路径概率与 I 处已有的权重相乘，正好成为 I' 中各历史的 $\pi_{-i}^{\sigma_{-i}^{(k)}}$ 。在遇到下一个本人信息集以前终止的路径上，两种策略的后续行为相同，故其第二项为零。

完全回忆使本人信息集及边 $(I, a) \rightarrow I'$ 组成一个森林。确切地说，同一信息集 I' 中的所有历史具有相同的本人既往信息集与行动序列，所以每个非根信息集都有唯一的前驱边；对手或机会的多条历史可以汇入同一个 I' ，但这些历史只在 $\pi_{-i}^{\sigma_{-i}^{(k)}}$ 的求和中合并，不会把 I' 复制成多个后继。记 $\tilde{\pi}_i(I)$ 为替代策略沿该唯一本人前缀的行动概率乘积；根信息集的乘积约定为 1。这正是反事实价值中故意省去的自身到达概率。

现在按一个信息集之后还可能遇到的本人信息集层数归纳。最深信息集没有后继, 式 (16.37) 给出 $D_i^{(k)}(I) = L_i^{(k)}(I)$ 。假设所有后续层数更少的后继子树都已展开, 把它们代回同一恒等式; 由于每个后继只有一个前驱, 子树中的每个信息集恰好出现一次, 其系数等于沿唯一前缀的 $\tilde{\sigma}_i$ 行动概率乘积。对森林的所有根求和后便得到

$$u_i(\tilde{\sigma}_i, \sigma_{-i}^{(k)}) - u_i(\sigma^{(k)}) = \sum_{I \in \mathcal{I}_i} \tilde{\pi}_i(I) \sum_{a \in A(I)} \tilde{\sigma}_i(a | I) r_i^{(k)}(I, a). \quad (16.38)$$

参与者 i 从未行动就终止的历史在两种策略下收益相同, 因而不出现在右侧。式 (16.38) 明确分开了两类权重: 对手与机会的权重已经包含在 $r_i^{(k)}(I, a)$ 中, 自身在替代策略下到达 I 的权重则是外部系数 $\tilde{\pi}_i(I)$ 。

替代策略固定后, $\tilde{\pi}_i(I)$ 和 $\tilde{\sigma}_i(a | I)$ 都不随 k 变化。对式 (16.38) 求和, 并使用 $0 \leq \tilde{\pi}_i(I) \leq 1$, 可得

$$\begin{aligned} & \sum_{k=1}^K \left[u_i(\tilde{\sigma}_i, \sigma_{-i}^{(k)}) - u_i(\sigma^{(k)}) \right] \\ &= \sum_I \tilde{\pi}_i(I) \sum_a \tilde{\sigma}_i(a | I) R_i^{(K)}(I, a) \\ &\leq \sum_I \tilde{\pi}_i(I) \max_a R_i^{(K)}(I, a) \leq \sum_I R_{i,+}^{(K)}(I). \end{aligned}$$

最后一个不等式也覆盖 $\max_a R_i^{(K)}(I, a) < 0$ 的情形, 因为此时相应正部为零。右侧与替代策略无关, 再对 $\tilde{\sigma}_i$ 取最大, 就得到式 (16.35)。 ■

若缺少完全回忆, 同一当前信息集可能汇合不同的本人行动历史。此时局部策略无法知道应该补回哪条自身到达路径, 上述递归可能重复计算或遗漏偏离收益, 局部低遗憾便不再自动控制整局外部遗憾。

结合式 (16.32), CFR 得到

$$R_i^{(K)} \leq \sum_{I \in \mathcal{I}_i} \Delta_I \sqrt{|A(I)|K}. \quad (16.39)$$

当信息集和行动数固定时, 平均正外部遗憾 $[R_i^{(K)}]_+/K = O(K^{-1/2})$, 因而趋于零。

有限树与有界终局收益保证可以为各信息集选择有限的 Δ_I 。这个界针对遍历完整树、准确计算反事实价值的版本, 不依赖末次策略是否单调改善。若信息集本身改变、遗忘破坏完全回忆, 或采样值存在未控制的偏差, 须重新检查分解与局部算法, 不能只引用 CFR 名称。

16.5.4 累计保证与平均策略表现

累计界要转成均衡误差，还需选对平均方式。一般和博弈保留共同轮次形成的联合分布；两人零和博弈借助收益的分别线性，把双方的独立平均策略与鞍点差距连接起来。历史树中还须先平均实现计划，才能恢复合法的行为策略。

16.5.4.1 一般和条件下的经验分布保证

令第 k 轮实际联合行动为 $\mathbf{a}^{(k)}$ ，经验联合分布为

$$\hat{\mu}^{(K)}(\mathbf{a}) = \frac{1}{K} \sum_{k=1}^K \mathbb{I}\{\mathbf{a}^{(k)} = \mathbf{a}\}.$$

若第 i 方的外部收益遗憾不超过 $\varepsilon_i K$ ，则对任意固定行动 a'_i ，直接把累计不等式除以 K 便得

$$\mathbb{E}_{\mathbf{A} \sim \hat{\mu}^{(K)}}[u_i(\mathbf{A})] \geq \mathbb{E}_{\mathbf{A} \sim \hat{\mu}^{(K)}}[u_i(a'_i, \mathbf{A}_{-i})] - \varepsilon_i.$$

这正是第 16.3.4 节的 CCE 不等式加上误差。若所有参与者的平均正外部遗憾趋零，有限联合单纯形的紧性保证经验分布的每个极限点都满足 CCE 条件，也保证其到 CCE 集合的距离趋零；未必存在唯一的极限分布。

若每个有向替换 $a_i \rightarrow b_i$ 的平均内部遗憾至多 ε_i ，那么对任意映射 $\phi_i : A_i \rightarrow A_i$ ，有

$$\begin{aligned} & \mathbb{E}_{\hat{\mu}^{(K)}}[u_i(\phi_i(A_i), \mathbf{A}_{-i}) - u_i(\mathbf{A})] \\ &= \frac{1}{K} \sum_{a_i \in A_i} R_{a_i \rightarrow \phi_i(a_i)}^{(K)} \leq |A_i| \varepsilon_i. \end{aligned}$$

这里的 R 已改写为收益约定。有限个有向替换控制了所有按建议改动的映射，所以无内部遗憾给出经验联合分布的 CE 极限点。若算法直接控制所有映射的交换遗憾，松弛就是 ε_i ，不必再乘 $|A_i|$ 。这个比较不会把普通外部遗憾算法自动升级为内部遗憾算法。

保留联合相关性确实必要。例如双方行动均为 A, B ，以第 1 方的行动为行、第 2 方的行动为列，各格列出双方收益：

	A	B
A	(2, 2)	(0, 0)
B	(0, 0)	(1, 1)

若实际序列一半轮次为 (A, A) 、一半为 (B, B) ，每人平均得 $3/2$ ，改用固定 A 只能得 1，改用固定 B 只能得 $1/2$ ；按建议单独改动也无利。经验分布是 CE。两方边缘平均却都是 $(1/2, 1/2)$ ，将它们独立相乘后，一方对该边

缘选 A 得 1、选 B 得 $1/2$ ，混合只得 $3/4$ ，所以平均边缘的乘积不是 Nash 均衡。

这些是对已记录联合序列的代数结论。若算法控制的是期望损失遗憾，而这里使用抽样行动，还须估计两者之间的随机误差；每轮独立抽样也不消除跨轮共同变化产生的相关性。

16.5.4.2 零和条件下的平均策略保证

矩阵博弈中， $\bar{\mathbf{x}}^{(K)} = K^{-1} \sum_k \mathbf{x}^{(k)}$ 与 $\bar{\mathbf{y}}^{(K)} = K^{-1} \sum_k \mathbf{y}^{(k)}$ 仍在各自单纯形内。固定一方策略时，双线性收益可把另一方的平均移进或移出求和。历史树中的行为概率却在同一条路径上相乘，逐信息集算术平均一般没有这项性质。

仍用例 16.30 的小树，考虑表 16.4 中的两轮策略。先等概率抽取一轮，再执行该轮的完整策略，终局 L 的概率为 $(1+0)/2 = 1/2$ 。若分别平均两个节点的行动概率，就会得到 $\bar{p} = \bar{q} = 1/2$ ，从而把终局 L 的概率改成 $\bar{p}\bar{q} = 1/4$ 。错误来自第二轮的 $q^{(2)} = 0$ ：这一轮始终退出，第二步怎样选择本来都没有作用，普通平均却把这个未执行的安排与第一轮同等计入。

轮次 k	$p^{(k)}$	$q^{(k)}$	终局 L 概率
1	1	1	1
2	0	0	0

表 16.4 两层小树中的两轮完整策略。 $p^{(k)}$ 表示进入概率， $q^{(k)}$ 表示进入后选 L 的概率，最后一列为 $p^{(k)}q^{(k)}$ 。第二轮不进入，故该轮第二步的安排不影响终局分布。这些数值只用于比较策略平均方式，不表示 CFR 必然产生这样的两轮轨迹。

按本人到达权重平均第二步，则

$$\bar{q} = \frac{p^{(1)}q^{(1)} + p^{(2)}q^{(2)}}{p^{(1)} + p^{(2)}} = 1, \quad \bar{p} = \frac{1}{2},$$

使 $\bar{p}\bar{q} = 1/2$ ，恢复完整策略混合的终局概率。若两轮都不进入，分母为零，此时任意 $\bar{q}$ 都与 $\bar{p} = 0$ 组合成相同终局分布。这个计算依赖 I_1 有唯一本人前缀 $I_0 \xrightarrow{E} I_1$ ；完全回忆把这一性质推广到一般信息集，才能逐层恢复平均后的实现权重。

行为策略不能在每个信息集直接做普通算术平均。某轮中一个信息集若几乎不会被参与者自己到达，该处局部概率不应与频繁到达轮次具有同样权重。完全回忆保证同一信息集 I 中的历史具有同一条本人行动前缀，因而 $\pi_i^{\sigma^{(k)}}(I)$ 定义为这条前缀上的本人行动概率乘积，与选取哪个 $h \in I$ 无关。记第 k 轮在本人序列 (I, a) 上的实现权重为

$$x_i^{(k)}(I, a) = \pi_i^{\sigma^{(k)}}(I) \sigma_i^{(k)}(a | I),$$

并令 $\bar{x}_i^{(K)}(I, a) = K^{-1} \sum_k x_i^{(k)}(I, a)$ 以及 $\bar{x}_i^{(K)}(I) = K^{-1} \sum_k \pi_i^{\sigma^{(k)}}(I)$ 。CFR 使用

$$\bar{\sigma}_i^{(K)}(a | I) = \frac{\sum_{k=1}^K \pi_i^{\sigma^{(k)}}(I) \sigma_i^{(k)}(a | I)}{\sum_{k=1}^K \pi_i^{\sigma^{(k)}}(I)}, \quad (16.40)$$

其中分母为零时可以任意指定。式 (16.40) 等价于

$$\bar{\sigma}_i^{(K)}(a | I) = \frac{\bar{x}_i^{(K)}(I, a)}{\bar{x}_i^{(K)}(I)}.$$

这个权重不是经验修正，而是实现计划平均所要求的条件概率。根本人序列的实现权重为 1。若 I 的唯一本人前驱序列终止于 (J, b) ，则每一轮都有 $\pi_i^{\sigma^{(k)}}(I) = x_i^{(k)}(J, b)$ ，对轮次平均后仍有 $\bar{x}_i^{(K)}(I) = \bar{x}_i^{(K)}(J, b)$ 。从根序列归纳，并在每个信息集应用上面的条件概率公式，得到

$$\pi_i^{\bar{\sigma}_i^{(K)}}(I) \bar{\sigma}_i^{(K)}(a | I) = \bar{x}_i^{(K)}(I, a) = \frac{1}{K} \sum_{k=1}^K x_i^{(k)}(I, a). \quad (16.41)$$

因此，加权平均行为策略实现的正是各轮本人实现计划的算术平均。分母为零意味着所有轮次到达该本人序列的概率都为零，此处怎样指定局部策略都不改变平均实现计划。

在两人零和博弈中，若双方累计外部遗憾分别不超过 $\varepsilon_1 K$ 与 $\varepsilon_2 K$ ，则平均策略满足

$$\max_{\sigma_1} u_1(\sigma_1, \bar{\sigma}_2^{(K)}) - \min_{\sigma_2} u_1(\bar{\sigma}_1^{(K)}, \sigma_2) \leq \varepsilon_1 + \varepsilon_2. \quad (16.42)$$

下面补出这个界。记第 k 轮第 1 位参与者的收益为 $u_1(\sigma_1^{(k)}, \sigma_2^{(k)})$ ，并令

$$\hat{u}^{(K)} = \frac{1}{K} \sum_{k=1}^K u_1(\sigma_1^{(k)}, \sigma_2^{(k)}).$$

终止历史 z 的概率可以写成机会概率与双方实现权重之积，所以期望收益对双方实现计划分别线性。结合式 (16.41)，对任意固定策略 σ_1, σ_2 有

$$\begin{aligned} \frac{1}{K} \sum_{k=1}^K u_1(\sigma_1, \sigma_2^{(k)}) &= u_1(\sigma_1, \bar{\sigma}_2^{(K)}), \\ \frac{1}{K} \sum_{k=1}^K u_1(\sigma_1^{(k)}, \sigma_2) &= u_1(\bar{\sigma}_1^{(K)}, \sigma_2). \end{aligned} \quad (16.43)$$

第 1 位参与者的外部遗憾界除以 K ，再用第一条等式，得到

$$\max_{\sigma_1} u_1(\sigma_1, \bar{\sigma}_2^{(K)}) - \hat{u}^{(K)} \leq \varepsilon_1. \quad (16.44)$$

第 2 位参与者的收益为 $u_2 = -u_1$ 。把其外部遗憾界同样除以 K ，并用式 (16.43) 的第二条等式，得到

$$\hat{u}^{(K)} - \min_{\sigma_2} u_1(\bar{\sigma}_1^{(K)}, \sigma_2) \leq \varepsilon_2. \quad (16.45)$$

将式 (16.44) 与 (16.45) 相加，经验对局收益 $\hat{u}^{(K)}$ 消去，正好得到式 (16.42)。若博弈值为 v^* ，其左侧还可写成

$$\left[\max_{\sigma_1} u_1(\sigma_1, \bar{\sigma}_2^{(K)}) - v^* \right] + \left[v^* - \min_{\sigma_2} u_1(\bar{\sigma}_1^{(K)}, \sigma_2) \right].$$

两项分别衡量第 2 位和第 1 位参与者的平均策略可被最佳响应利用多少，且都非负；因此该和是双方平均策略的零和鞍点间隙。本章把这个和称为联合可利用度 (joint exploitability)；若采用两项平均的口径，数值还需除以 2。间隙为零时，两者构成极小极大策略对。

三张牌中每人只行动一次，各自信息集没有本人先前行动，权重恰好都为 1；因此这个特例可以直接平均 b_H, b_L, c ，不能据此推广到多步决策。

式 (16.42) 保证的是两人零和博弈的平均策略，而非末项。有限完全回忆时，合法平均和极小极大结构共同支持这项结论；一般和的联合经验分布结论已在上一小节单独建立。

末次策略还可能持续循环。采样 CFR 若只访问部分历史，还要用第 10 章的无偏估计、方差和集中工具控制采样误差，不能把完整树上的确定性分解直接当作有限样本保证。

回到三张牌例子，在均衡候选下，高牌质询与低牌质询的权重为 $1/2$ 和 $1/6$ 。实际迭代则要使用本轮的权重 $b_H^{(k)}/2$ 与 $b_L^{(k)}/2$ ，计算参与者 2 的局部应对遗憾。若累计遗憾使算法提高 C 的概率，这一变化又会降低低牌质询的收益，使参与者 1 减少虚张声势。双方局部更新相互改变下一轮价值，CFR 保证累计偏离受控，却不要求这两个概率逐轮单调走向 $1/3$ 。

把平均遗憾转成均衡结论时，还要保留产生平均的联合样本。表 16.5 比较两种偏离：固定行动只提出一个事前替代选择，内部替换可以对某种已采取行动单独修改，因此后者需要控制更多比较。这里的保证针对经验联合分布或相应的平均策略，不对最后一轮作同样承诺。

偏离比较	允许怎样改变	一般和下的平均结论	两人零和的补充
外部遗憾	所有轮次统一改用一个固定行动	经验联合分布的粗相关偏离收益小	双方平均策略的鞍点差距小
内部遗憾	将某种已选行动统一换成另一行动	经验联合分布的相关偏离收益小	仍需按具体信息结构恢复策略

表 16.5 遗憾的比较类与平均结论。表中要求每位参与者都控制相应的平均遗憾；扩展式博弈的平均行为策略还须使用自身到达权重。末次策略收敛不由这些平均结论推出。

16.6 本章小结

多方选择使行动的后果取决于联合策略。信息集先限制每人能够实施的完整计划，到达概率再把这些计划变成各方整局价值。完全回忆保证混合计划与行为策略的实现等价，也为后面的局部遗憾分解提供唯一本人前缀。三张牌博弈中，是否看得见隐藏牌会改变合法策略，不只是改变收益估计。

固定其他策略后可求最佳响应，相互响应形成 Nash 条件。有限混合均衡的存在依赖最佳响应集合非空、紧、凸，以及上半连续等条件；本章通过 Sperner、Brouwer 与 Kakutani 定理建立了这一存在性结论，不意味着唯一、容易计算或能够被任意学习过程找到。零和极小极大把双方保证写成一对线性规划，三张牌的 2/3 由原对偶可行证书共同确认。共同建议则改变偏离时可用的信息，得到 CE 与 CCE 各自的约束；它们不能与独立混合 Nash 无条件互换。

给定更新规则以后，才能检验其不动点和稳定性。双加热器的一步响应误差可以收缩，但这与局内温差在固定反馈下的衰减是两套计算。匹配硬币同时响应会形成四周期，同时离散梯度在中心附近会放大扰动，连续梯度或复制动态还可能沿闭轨道运行。ESS 另行检验少量新策略的入侵，不能用名称中的“稳定”代替指定更新的分析。

即使逐轮策略没有收敛，累计比较仍有意义。投影次梯度用固定比较点的距离递推给出 $O(\sqrt{K})$ 外部遗憾；CFR 保留对手与机会的反事实权重，再沿完全回忆的信息集森林汇总局部偏离。在一般和博弈中，各人的平均外部遗憾趋于零时，经验联合分布接近 CCE；各人的平均内部遗憾趋于零时，则接近 CE。两人零和的双方遗憾则控制合法平均策略的联合可利用度。平均行为策略须由平均实现计划恢复，不能逐位置任意平均，也不能把完整树的确定性证明当作采样保证。

合作价值回答另一类问题。Shapley 值在联盟价值已定义后按加入顺序平均边际贡献，并由四项公理唯一刻画；它既不保证成员不退出，也不把预测归因变成因果贡献。核心要求没有联盟能靠退出取得更多收益，Pareto 条件要求没有方案能让所有人不变差且至少一人变好。Nash 乘积协商在声明的紧凸可行域、共同严格增益和分歧点下选择唯一收益向量。公平分配、无获利偏离、动态稳定、逐轮策略的收敛和无遗憾各有比较对象与条件，任何一项都不能仅凭另一项的名称推出。下一章将把这些保证放回后续机器学习任务，比较它们各自回答的问题。

第六部分

数学与机器学习

Mathematics and Machine Learning

阅读指引

用温度记录训练出一个误差很小的模型，是否就能在实际运行中准确预警、安全散热？回答这个问题，需要分清记录包含什么信息、训练目标是否代表实际要求，以及算法得到的模型在新记录 and 真实执行中表现如何。前五个部分建立的函数、空间、随机变量、状态与策略等数学语言，在本部分用来说明这些环节：环境与观测机制决定记录怎样产生，采样规则决定记录之间的关系；损失与约束规定任务要求，候选类与优化规则决定算法怎样利用记录取得结果。有行动参与的交互任务，还要说明行动如何改变后续状态和新记录。

本部分只有第 17 章“数学基础与后续研究”。该章从温度预测与调节的问题出发，先明确数学对象，再将表达、训练、泛化和部署中的实际问题写成“在什么对象上进行什么分析”。纠正标签或更换优化器后，模型改变多少？普通工况中的记录，能否评价高负载下的表现？这两个问题需要不同的比较对象和条件。迁移与强化学习还需明确来源和目标的分布关系，以及策略怎样影响后续观测。随后将这些疑问按所研究的数学对象归类：观测与分布、候选函数、训练目标及其最优解、计算序列、数据到模型的学习映射，以及策略执行的闭环轨迹。每类问题先说明困难，再作正式表述，并解释前五部分的知识在什么条件下能够帮助回答。本章提供问题与工具的对应；具体模型中的推导、求解方法及结论，由后续各卷在相应场景中建立。

数学基础与后续研究

设想我们用设备在普通负载下的温度记录训练一个预测器。训练误差已经很小，它就能在高负载时准确预警，并帮助设备安全散热吗？未必。传感器可能漏掉了影响温度的工况，候选模型可能无法表达真正的温度规律，有限记录也可能没有包含高负载下的危险情形。即使预测温度足够准确，以平均误差为目标得到的模型，也未必满足漏报率或安全温度的要求。要回答这些疑问，必须沿着数据生成、训练、评价和实际执行的过程，分清每一步究竟解决了什么问题。

前面各章已经介绍集合与映射、随机变量与分布、最优化与动态系统。本章用这些语言说明数据怎样产生、任务要求是什么、学习方法怎样得到结果，再将实际疑问写成明确的数学问题：给定什么，想确定什么，需要哪些条件。随后把结构相同的问题归在一起，说明前文的数学知识怎样帮助回答它们。这样才能判断两个名称不同的问题是否共用同一种分析，以及同一个“鲁棒性”要求为什么有时研究固定函数，有时研究整个训练过程。本章建立问题与数学工具的联系；各类模型的具体算法和专门保证由后续各卷展开。读完本章，应能把一个实际疑问写成对象、比较量和成立条件明确的数学问题，并找到前面各章中可供分析的知识入口。

17.1 学习的组成：数据、目标与学习方法

数据说明经验从哪里来、记录了什么；目标说明哪些结果值得选择、哪些结果不可接受；学习方法说明允许选择哪些候选，以及怎样利用数据找到一个候选。为了让这三类说明能够进入公式，必须区分集合、函数、概率分布和一次实际观测。先考虑用已有记录预测温度的任务；随后再加入自动散热行动，说明行动改变未来温度时，学习过程需要怎样扩展。

17.1.1 数据：环境、观测机制与有限样本

温度预测首先需要分清真实发生的情形和传感器留下的记录。在静态设定中，用 $s \in S$ 表示一次真实情形。例如 s 可以包含设备的真实温度、工况

和下一时刻的真实温度。这些量未必全部可见。选定可测空间 (S, Σ_S) 与其上的概率测度 μ ，本章将

$$\mathcal{E} = (S, \Sigma_S, \mu) \quad (17.1)$$

称为静态环境模型。 S 列出可能情形， Σ_S 规定哪些情形事件可以讨论概率， μ 规定这些事件的发生概率。例如，设备是否处于高负载就是一个事件，它的概率由 μ 给出。 $\mathcal{E}$ 描述这些情形及其概率规律， s 才是其中某一次具体情形。这是一种建模约定；动态环境还要包含状态转移规律，稍后单独定义。

环境中的情形怎样成为可用记录，需要另给观测机制。令 (Z, Σ_Z) 为记录空间，观测机制为从 S 到 Z 的概率核 (probability kernel) K 。它是二元函数 $K : S \times \Sigma_Z \rightarrow [0, 1]$ ：固定 s 后， $K(s, \cdot)$ 是记录空间上的概率测度；固定可测记录事件 B 后， $s \mapsto K(s, B)$ 是可测函数。也就是说， $K(s, B)$ 回答的是：真实情形为 s 时，有多大概率得到属于 B 的记录？它可以同时包含传感器噪声、特征提取、缺失和标注过程。将记录空间与核合记为 $\mathcal{O} = (Z, \Sigma_Z, K)$ 。

令 V 为取值于 S 的随机变量， Z 为取值于 Z 的记录随机变量。指定 $V \sim \mu$ 以及给定 $V = s$ 时的记录律 $K(s, \cdot)$ ，便得到

$$P(B) = \mathbb{P}\{Z \in B\} = \int_S K(s, B) \mu(ds), \quad B \in \Sigma_Z. \quad (17.2)$$

记 $P = \mu K$ 。式中 P 是记录的分布， Z 是随机变量， z 是它的一次实现。随机变量本身仍是从底层概率空间到取值空间的可测映射； $V \sim \mu$ 与 $Z | V = s \sim K(s, \cdot)$ 规定其联合分布，描述两阶段抽样。从 (μ, K) 计算 P 是确定的分布运算，从 P 取得一次 z 则是随机试验。

确定性观测是这个定义的特例。若记录由可测函数 $g : S \rightarrow Z$ 给出，就有 $Z = g(V)$ 、 $K(s, \cdot) = \delta_{g(s)}$ ，其中 $\delta_{g(s)}$ 是在 $g(s)$ 处的点质量；此时 $P = g_{\#}\mu$ 是推前测度。为了看清传感器噪声如何进入核，设真实情形 $s = (v, y)$ 包含当前与后继温度，记录为 $(v + \xi, y)$ ，其中 ξ 是独立测量噪声。给定 s 后仍需抽取 ξ ，所以通常不存在仅以 s 为输入的确定性记录函数；把噪声也列为输入以后， $(s, \xi) \mapsto (v + \xi, y)$ 才是确定性映射。这说明“通过函数生成”和“按分布采样”可以描述同一生成过程的不同层次。

一条记录的分布还没有规定多条记录的关系。采样机制 Γ_n 指定预算为 n 时整批记录的联合律，记为 $Q_n = \Gamma_n(\mathcal{E}, \mathcal{O})$ ，它是 Z^n 上的概率测度。机制本身包含独立抽取、连续采集或按历史选择等规则；单次边缘分布 P 不能决定这些规则。有限样本写为有序记录组 $D = (Z_1, \dots, Z_n)$ ，以保留顺序和重复记录。独立同分布 (independent and identically distributed, i.i.d.) 采样的特例为

$$D \sim Q_n = P^{\otimes n}, \quad P^{\otimes n} \text{ 也简记为 } P^n. \quad (17.3)$$

上述分布用于定义问题，可以是学习者未知的真实规律；写出它们不表示算法能够读取它们。抽样前还不知道会取得哪些记录，因此 D 是随机对象；抽样后得到一组确定记录，后文为简洁仍记为 D 。设备更常处于高负载，会改变环境规律 μ ；换用不同精度的传感器，会改变观测核 K ；只在报警后采集数据，会改变采样机制 Γ_n ；纠正一条已取得的标签，则直接修改 D 。这些变化发生在不同环节，后面分析它们对学习结果的影响时，也需要分别说明。

17.1.2 目标：损失、评价分布与约束

记录本身没有规定什么叫预测得好。令 H 为当前任务中所有允许讨论的决策对象组成的空间；在监督预测中，它可以是从输入空间 X 到输出空间 Y 的可测函数空间。用 $\ell : H \times Z \rightarrow \mathbb{R}$ 给每个候选 h 及记录 z 计分，并假定所讨论的损失可测、相关期望有限。例如 $z = (x, y)$ 时，可取 $\ell(h, z) = (h(x) - y)^2$ 。在无监督任务中 z 可以只有 x ，但仍需明确重构、分组或密度拟合的计分规则。

同样的预测误差，若发生在常见工况或罕见工况，在平均评价中占的权重就不同。评价分布规定各类错误按什么频率计入目标。静态任务中给定评价记录律 P ，总体风险为

$$R_P(h) = \int_Z \ell(h, z) P(dz). \quad (17.4)$$

ℓ 是以候选和记录为输入的函数， R_P 是以候选为输入、输出一个实数的泛函。训练分布 P_{tr} 、验证分布 P_{va} 与测试分布 P_{te} 需要分别指定；只有明确作出同分布假设时才统一记为 P 。训练集用于学习，验证集用于选择配置，测试集用于评估训练及选择后的结果。这些职责不自动保证各组样本独立或同分布；测试分布代表哪个总体，是风险定义的一部分。

约束 $\mathcal{C} \subseteq H$ 是满足任务要求的决策集合。它可以由一组条件定义，例如 $\mathcal{C} = \{h : c_j(h) \leq 0, j = 1, \dots, m\}$ ，其中 c_j 是约束泛函， m 是约束数目。对温度预测器，条件可以限制指定工况下的大误差概率；对加热策略，则可以限制越过安全温度的概率。这些总体条件依赖未知分布时，训练中采用的经验约束只是一种估计，必须另行检查总体可行性。最小化平均损失与满足约束是两项要求；把违规代价加入损失也会形成新的目标，不能未经分析就认定它等价于硬约束。本章将损失与候选约束合记为目标设定 $\mathcal{T} = (\ell, \mathcal{C})$ ，评价分布由数据设定给定。这里 $\mathcal{C}$ 约束的是候选行为。若要求限制算法的隐私泄露或计算资源，约束的对象就应改为学习机制或计算过程；后文会在相应对象上单独写出这些条件，不能把机制的隐私保证当成一个固定预测函数的性质。

17.1.3 学习方法：候选类、目标构造与优化规则

同样用温度记录训练，选择仿射模型与选择神经网络，能够学到的温度规律可能不同。因此，学习方法首先要限定可选择的候选类 $\mathcal{H} \subseteq \mathbf{H}$ 。参数化是映射 $\Phi: \Theta \rightarrow \mathcal{H}$ ，其中 $\Theta \subseteq \mathbb{R}^p$ 为参数集合， p 为参数维度， $h_\theta = \Phi(\theta)$ 为对应候选。下文默认 $\mathcal{H} = \Phi(\Theta)$ ；若参数化不能覆盖给定候选类，实际分析范围应改为其像。可行候选类为 $\mathcal{H}_c = \mathcal{H} \cap \mathcal{C}$ 。由网络结构造成的候选限制属于方法，由任务规定的行为要求属于目标；二者虽然都能写成集合限制，改变它们时仍应说明限制的来源。

总体风险依赖真实分布，算法通常不能直接计算它。有了有限记录和任务目标以后，还要规定算法实际最小化哪个评分，这就是训练泛函 F_D 。用 B 表示目标构造规则。固定损失、约束和候选配置后，它是从 $\mathbf{Z}^n$ 到“实值泛函与候选子集”的映射，写为 $B(D) = (F_D, \widehat{\mathcal{H}}_{c,D})$ ，其中 $F_D: \mathcal{H} \rightarrow \mathbb{R}$ ， $\widehat{\mathcal{H}}_{c,D} \subseteq \mathcal{H}$ 是实际训练中使用的可行集。已知约束直接使用 $\mathcal{H}_c$ ；未知总体约束则需估计。在同分布且可直接观察损失的基准设定中，经验风险 (empirical risk) 是样本平均损失。以它为 F_D ，并在给定可行类中选择极小值，得到经验风险最小化 (empirical risk minimization, ERM)：

$$\widehat{R}_D(h) = \frac{1}{n} \sum_{i=1}^n \ell(h, Z_i), \quad \widehat{h}_D \in \arg \min_{h \in \mathcal{H}_c} \widehat{R}_D(h). \quad (17.5)$$

这里假定极小值能达到。加入正则项时可取 $F_D(h) = \widehat{R}_D(h) + \lambda \Omega(h)$ ，其中 Ω 为惩罚泛函、 $\lambda \geq 0$ 为权重。跨分布学习可能需要加权，缺失标签可能需要代理损失；这些构造都须解释怎样联系评价目标。训练中引入的计算便利条件也应与原任务要求区分。

训练评分确定以后，还没有得到模型。优化规则继续规定怎样初始化、更新和停止，从而在有限计算预算内输出一个候选。将初始化、小批量索引等算法随机性汇集为随机变量 U ，取值空间为 $\mathbf{U}$ 、分布为 ν 。固定方法配置后，第 k 步学习映射为

$$A^{(k)}: \mathbf{Z}^n \times \mathbf{U} \rightarrow \mathcal{H}, \quad h_D^{(k)} = A^{(k)}(D, U). \quad (17.6)$$

对不同样本数，实际使用映射族 $\{A_n^{(k)}\}$ ；上式省略下标 n 。比较删除或增加记录前后的输出时，分别调用对应样本数的成员。这里 $A^{(k)}$ 是目标构造与求解的复合映射； F_D 是其中的中间对象。若算法允许中间迭代违反约束， $A^{(k)}$ 的值仍属于 $\mathcal{H}$ ，却未必属于可行类；后面的风险最优化保证在使用可行性时会显式要求输出可行。为讨论输出概率，在候选空间上给定适当的可测结构，并要求 $A^{(k)}$ 可测。基准设定令 U 独立于 D 。有限预算固定后将输出简记为 h_D 。参数、动量等构成训练状态 $v_D^{(k)}$ ，优化器可以写成 $v_D^{(k+1)} = T_{D,k}(v_D^{(k)}, U_k)$ ，再从状态读出 $\theta^{(k)}$ 和 $h_D^{(k)}$ 。计算步 k 、样本数 n 和环境时间 t 是三个不同的索引。

将优化程序（含初始化、更新、停止与输出规则）记为 $\mathcal{A}$ ，学习方法是结构 $\mathcal{L} = (\mathcal{H}, \Phi, \mathcal{B}, \mathcal{A})$ 。对阶段 $r \in \{\text{tr}, \text{va}, \text{te}\}$ ，用 $\mathcal{G}_r = (\mathcal{E}_r, \mathcal{O}_r, \Gamma_r)$ 记录该阶段的环境、观测与采样规则族；数据设定为 $\mathcal{D} = (\mathcal{G}_{\text{tr}}, \mathcal{G}_{\text{va}}, \mathcal{G}_{\text{te}})$ 。因此 $\mathcal{D}$ 是配置结构，与一批实现样本 D 不同。完整学习设定记为

$$\mathcal{M} = (\mathcal{D}, \mathcal{T}, \mathcal{L}). \quad (17.7)$$

写 $R_{\mathcal{M}}$ 时，表示使用该设定中的评价分布和损失；静态情形仍简记为 R_P 。这里还要分清三个结果：总体解集合 $\mathcal{H}_{\mathcal{M}}^* = \arg \min_{h \in \mathcal{H}_c} R_{\mathcal{M}}(h)$ 包含在真实评价分布上表现最好的候选；理想训练解 $\hat{h}_D$ 最小化有限样本构造的训练目标；有限计算输出 $h_D^{(k)}$ 则是算法实际运行到第 k 步得到的候选。三者未必相同。样本随机性改变训练问题，算法随机性改变同一训练问题中的求解过程。

17.1.4 静态学习：训练、固定模型推理与独立评价

训练将整批数据映为候选 $D \mapsto h_D$ ；固定模型的推理则把一次输入映为输出 $x \mapsto h_D(x)$ 。监督任务中的记录 $z = (x, y)$ 用于计算损失，部署预测时通常只给模型 x 。标签 y 若需延迟获取，评价也须遵守这一信息条件。图 17.1 中的箭头分别表示确定的分布构造、随机采样、目标构造、求解与评价，不能都理解成同一种函数运算。




图 17.1 静态学习中的数据、目标与方法。蓝色节点表示数据对象，红色节点表示训练计算，黄色节点表示学得对象与评价结果。图中取独立采样 $Q_n = P_{\text{tr}}^n$ ； $P = \mu K$ 是分布运算， $D \sim Q_n$ 是采样。目标构造 B 与优化规则共同组成学习映射 A 。独立测试样本只用于估计指定的评价风险。

固定 h_D 以后，若另取独立测试集 $D_{\text{te}} \sim P_{\text{te}}^m$ ，样本平均 $\hat{R}_{D_{\text{te}}}(h_D)$ 估计的是 $R_{P_{\text{te}}}(h_D)$ 。这里的测试分布是当前任务规定的评价总体。若测试集实际来自另一分布，还须说明两者的联系，不能仅凭样本平均代表指定的测试风险。同一分布下两批有限样本不同，可以只是抽样波动；训练分布与测试分布不同，则需要增加分布之间的假设与分析。

17.1.5 交互学习：环境转移核与策略诱导的轨迹分布

加热行动会改变后继温度，这时单次情形分布不足以描述环境。在有限时域、受控 Markov 模型的简化设定中，取状态空间 (S, Σ_S) 、行动空间 (A, Σ_A) 、初始状态分布 μ_0 ，以及转移概率核 $T : S \times A \times \Sigma_S \rightarrow [0, 1]$ 。对每个 (s, a) ， $T(s, a, \cdot)$ 是下一状态的概率测度；对每个状态事件，核关于 (s, a) 可测。动态环境模型是结构

$$\mathcal{E} = (S, \Sigma_S, A, \Sigma_A, \mu_0, T).$$

与前面的静态环境相比，它增加了行动空间、初始状态分布和状态转移核。因此，下面仍用 $\mathcal{E}$ 表示环境，但其中已经包含行动怎样改变下一状态的规律。

观测核 $K_o : S \times \Sigma_O \rightarrow [0, 1]$ 在状态给定后生成观测 o_t ， (O, Σ_O) 为观测空间。可见反馈也可以包含在 o_t 中。令 $I_t = (o_0, a_0, \dots, a_{t-1}, o_t)$ 为可得历史；策略 π_t 是从历史空间到行动空间的概率核，给出 $\pi_t(da | I_t)$ 。确定性策略是点质量核，完全可观测情形才可直接以当前状态为输入。

固定环境、观测机制和策略。长度为 H 的理论轨迹记为

$$\tau = (s_0, o_0, a_0, \dots, a_{H-1}, s_H, o_H).$$

它的联合律为

$$P_{\mathcal{E}}^{\pi}(d\tau) = \mu_0(ds_0)K_o(s_0, do_0) \cdot \prod_{t=0}^{H-1} \pi_t(da_t | I_t)T(s_t, a_t, ds_{t+1})K_o(s_{t+1}, do_{t+1}). \quad (17.8)$$

$P_{\mathcal{E}}^{\pi}$ 的简记还隐含固定的 K_o 与时域 H ；比较观测机制时必须把其依赖恢复。每个因子对应一次条件采样，乘积规定整条轨迹的联合分布。理论轨迹可包含隐状态，实际记录只能包含采集到的字段；实际记录律是上述轨迹律经记录映射的推前。累计成本写为可积轨迹损失 $\ell(\pi, \tau)$ ，则 $R_{\mathcal{M}}(\pi) = \mathbb{E}_{P_{\mathcal{E}}^{\pi}}[\ell(\pi, \tau)]$ 。若损失依赖未观测状态，还需另行论证能否从记录识别它。

行为策略 β 采集训练轨迹样本，目标策略 π 是所要学习或评价的策略。为与静态学习的记录分布对应，以 T_H 表示长度为 H 的理论轨迹空间， Z_{rec} 为可见记录空间，固定可测记录映射 $b : \mathsf{T}_H \rightarrow \mathsf{Z}_{\text{rec}}$ 。轨迹律与记录分布分别是

$$P_{\mathcal{E}}^{\sigma}, \quad P_{\text{rec}}^{\sigma} = b_{\#}P_{\mathcal{E}}^{\sigma}, \quad \sigma \in \{\beta, \pi\}.$$

记录映射可以去掉隐状态等不可采集字段；它将轨迹律推前为实际记录分布。在独立重复完整运行的基准设定中，训练样本满足 $D \sim (P_{\text{rec}}^{\beta})^n$ 。固定学得策略 π 后，给定训练样本及算法随机性，用新的环境随机性独立重复

运行取得 $D_{\text{te}} \sim (P_{\text{rec}}^\pi)^m$ 。每个样本是一条完整轨迹的可见记录，同一条轨迹内的时刻并不因此独立。

即使两者使用同一环境， P_ε^β 与 P_ε^π 也可能不同。离线学习须说明旧策略的记录怎样支持新策略的评价；在线学习还会让后续采样依赖已有学习结果。图 17.2 中，两个策略连接同一个环境节点。采集阶段由 β 选择行动，执行阶段改用固定的 π ；每个阶段中，行动都反馈到环境，新的观测进入历史，再决定后续行动。两种策略与环境分别诱导轨迹律，经 b 得到可见记录分布，再采样得到有限轨迹样本。这与图 17.1 中由记录分布采样得到训练或测试样本的读法相同，但交互任务的分布还依赖参与生成数据的策略。

若存在可积的记录损失 ℓ_{rec} ，使 $\ell_{\text{rec}}(\pi, b(\tau)) = \ell(\pi, \tau)$ ，则对测试记录 $D_{\text{te}} = (Z_1, \dots, Z_m)$ ，总体风险与样本估计可以写为

$$R_{\mathcal{M}}(\pi) = \mathbb{E}_{P_{\text{rec}}^\pi}[\ell_{\text{rec}}(\pi, Z)],$$

$$\hat{R}_{D_{\text{te}}}(\pi) = \frac{1}{m} \sum_{j=1}^m \ell_{\text{rec}}(\pi, Z_j).$$

样本估计与总体轨迹风险的关系需要统计分析，不能从一次测试直接读取总体期望。

学习形式	数据与记录	目标	学习方法中的候选
有监督学习	输入、标签的联合记录 (x, y)	预测损失与行为约束	预测函数 $h: \mathbf{X} \rightarrow \mathbf{Y}$
无监督学习	无标签观测 x	重构、分组或密度目标	表示、簇中心或概率模型 q_h
强化学习	策略参与生成的轨迹记录	累计成本、负回报与轨迹约束	从可得历史选择行动的策略 π

表 17.1 三类学习任务使用相同的组成方式，但记录、候选和目标的具体类型不同。概率模型 q_h 给出的模型分布须与真实观测分布 P 区分。




图 17.2 同一环境中的交互学习及其分布、样本与评价。采集策略 β 与执行策略 π 分阶段接入同一个环境，行动返回环境，观测 o_t 进入历史 I_t 。蓝色为环境与数据对象，红色为训练计算，黄色为策略与评价结果。右侧沿用静态图的“分布-采样-样本-训练或评价”结构；记录分布由轨迹律经 b 推前得到。图示取完整运行之间独立、固定学得策略后重新采集测试轨迹，且轨迹损失可由可见记录计算。虚线分别表示期望定义与风险估计的统计分析。

17.2 机器学习问题的数学表述

前一节定义了学习设定中的组成。本节从具体任务出发，明确哪一个数学对象接受分析。一项完整表述要给出对象的类型、定义域和值域，说明哪些量固定、哪些量改变，再指定误差、距离、事件或极限。例如，固定样本 D 后的预测函数 $h_D : X \rightarrow Y$ ，与把样本映成预测函数的 $A^{(k)} : Z^n \times U \rightarrow \mathcal{H}$ ，是两个不同的映射。前者接受输入 x 的扰动，后者接受训练样本 D 的扰动，不能只用“模型鲁棒性”代替这一差别。

以下沿用温度预测、越限预警与自动散热的教学场景。对可测空间 B ，以 $\mathcal{P}(B)$ 表示其上的概率测度集合，以 2^B 表示其所有子集组成的集合。涉及随机映射与上确界事件时要求可测，涉及积分时要求可积；条件分布在其存在的空间中讨论。函数距离、集合距离与概率测度距离分别指定，不能把这些对象都当成可直接相减的实数。本节在实际任务中写出对象与分析量；下一节合并相同数学结构的问题，给出正式问题和数学工具的入口。

17.2.1 信息与表达：观测能支持什么，候选能表示什么

设设备需要提前一段时间预测温度，输入 x 包含温度读数、负载或控制记录，标签 y 是指定时距后的温度。回归预测器 $h : X \rightarrow \mathbb{R}$ 输出温度值，平方损失为 $\ell(h, (x, y)) = (h(x) - y)^2$ 。若改为越限预警，则由阈值 c 构造二元标签 $\{y > c\}$ ，候选的输出空间和漏报、误报的损失也随之改变。同一批原始记录可以服务于不同的数学任务。

如果加热动作影响后继温度，却没有进入记录，不同的作用机制可能产生相同的温度记录分布。为表述这种信息歧义，固定状态空间、记录空间和观测核 K ，令 $\mathfrak{E}$ 为允许的静态环境模型集合， J 为目标量的取值空间。先考虑独立重复采样 $Q_n^\mathfrak{E} = (\mu K)^{\otimes n}$ ，此时单条记录的分布决定全部样本律。需要分析的是两个映射

$$\begin{aligned} \Xi : \mathfrak{E} &\rightarrow \mathcal{P}(Z), \quad \Xi(\mathcal{E}) = \mu K, \\ J : \mathfrak{E} &\rightarrow J, \quad \mathcal{E} \mapsto J(\mathcal{E}). \end{aligned} \tag{17.9}$$

Ξ 输出可观测记录的分布， J 输出希望确定的温度规律或参数。能否由记录确定所求量，取决于下面的关系：对任意 $\mathcal{E}, \mathcal{E}' \in \mathfrak{E}$ ， $\Xi(\mathcal{E}) = \Xi(\mathcal{E}')$ 是否蕴含 $J(\mathcal{E}) = J(\mathcal{E}')$ 。如果两种环境产生相同的记录分布，却对应不同的目标量，那么单凭这些记录就无法分清哪一个答案正确。增加同类记录可以更准确地估计记录分布，却不能消除这种歧义。若实际采用相关或自适应采样，应将 Ξ 改为完整可观测联合律或观测实验族 $(Q_n^\mathfrak{E})_n$ 。单条记录的边缘律相同，并不意味着多条记录之间的关系也相同，后者可能提供额外信息。若所求量是干预效果，应先将因果结构加入环境模型，再定义 J 与相应的观测映射；仅给出静态观测分布还没有定义一个干预模型。

信息充分以后, 还要检查方法允许的候选能否表示所需规律。例如, 仿射函数不能在非退化区间上处处表示二次温度规律。固定参考函数 $g \in H$ 、函数距离 d_H 和表示映射 $\Phi: \Theta \rightarrow \mathcal{H} \subseteq H$, 令 $\Theta_{\mathcal{C}} = \{\theta \in \Theta: \Phi(\theta) \in \mathcal{C}\}$ 。为了判断候选范围够不够用, 需要比较实际可表示的函数集合与参考函数 g :

$$\mathcal{H}_{\mathcal{C}} = \Phi(\Theta_{\mathcal{C}}), \quad e_{\text{app}}(g) = \inf_{\theta \in \Theta_{\mathcal{C}}} d_H(\Phi(\theta), g).$$

精确表示问 g 是否属于这个像; 逼近问误差下确界多大、能否达到。相等和距离应按任务规定为逐点意义或几乎处处意义。这还没有分析训练是否找到相应候选; 模型压缩和行为解释可以沿用此对象, 只需更换参考函数 g 。

有限记录能否恢复设备参数或连接结构, 是在识别之后提出的统计问题。给目标空间 J 选定距离 d_J , 估计器是映射

$$\hat{J}_n: Z^n \times U \rightarrow J, \quad e_n(D, U; \mathcal{E}) = d_J(\hat{J}_n(D, U), J(\mathcal{E})).$$

固定环境 $\mathcal{E}$ 后, $D \sim Q_n^{\mathcal{E}}$ 、 $U \sim \nu$ 使 e_n 成为非负随机变量; $Q_n^{\mathcal{E}}$ 表示该环境及既定观测、采样机制所诱导的样本律。恢复是否准确, 可以用误差超过 ϵ 的概率 $\mathbb{P}\{e_n > \epsilon\}$ 衡量。再问样本数 n 不断增加时, 这个概率是否趋于零, 就得到一致性问题。若目标只确定到坐标变换或类别置换, 应先把 J 取为相应等价类空间。预测风险小与这个恢复误差小, 是不同的要求。

传感器重新编号时, 模型的输出也应遵守任务语义。令群 G 在输入、输出空间上的作用分别为 $\rho_X: G \times X \rightarrow X$ 和 $\rho_Y: G \times Y \rightarrow Y$ 。为判断重新编号后输出是否作出相应变化, 要检查固定候选 h 是否满足

$$h(\rho_X(\gamma, x)) = \rho_Y(\gamma, h(x)), \quad \gamma \in G, x \in X.$$

这给出等变性; 输出作用为恒等时得到不变性。另一个问题是压缩表示是否丢掉了任务需要的信息。给定表示映射 $r: X \rightarrow Z_r$ 与任务函数 $f: X \rightarrow Y$, 如果存在 $\tilde{f}: Z_r \rightarrow Y$ 使 $f = \tilde{f} \circ r$, 就能仅凭表示 $r(x)$ 得到任务答案 $f(x)$ 。前者比较变换前后的对应关系, 后者检查表示合并的输入是否仍需不同答案。

若要补全缺失读数或推断隐藏故障, 固定的对象可以是模型概率测度 $Q_h \in \mathcal{P}(X \times V_{\text{lat}})$, 其中 V_{lat} 是隐变量空间。为了从可见读数推断隐藏故障, 需要从这个模型计算边缘测度 $Q_{h,X}$ 、条件概率核 $Q_h(dv | x)$, 或条件积分 $\int a(v)Q_h(dv | x)$; a 是指定的可积查询函数。条件核由联合律在 $Q_{h,X}$ 几乎处处意义下确定。固定观测 x 后, 若预算 m 的采样算法最终输出一个隐变量, 其律为 $\tilde{Q}_m \in \mathcal{P}(V_{\text{lat}})$, 还要在该测度空间上比较它与所求条件律的距离。图模型另给图 $\mathcal{G} = (V_G, E_G)$, 以 z 表示图中变量的联合取值。在有向无环图及相应密度存在的设定中, 用 q_h 表示密度, 分解分析检查

$q_h(z) = \prod_{i \in V_G} q_h(z_i | z_{\text{pa}(i)})$ 及其条件独立含义, $\text{pa}(i)$ 是结点 i 的父结点集合。这些分析固定模型分布; 它在可观测字段上的边缘律是否符合现实记录律 P , 还需另外做统计验证。

17.2.2 训练与求解: 优化问题的解和算法产生的序列

固定记录 D 以后, 温度回归可使用平均平方误差加正则项。目标构造规则给出实值泛函 $F_D : \mathcal{H} \rightarrow \mathbb{R}$ 和训练可行集合 $\mathcal{K}_D = \widehat{\mathcal{H}}_{e,D} \subseteq \mathcal{H}$ 。在讨论算法能否求解之前, 先问这个训练问题有没有最优候选。固定目标和可行集 $(F_D, \mathcal{K}_D)$, 需要确定最优值和达到该值的候选集合:

$$F_D^* = \inf_{h \in \mathcal{K}_D} F_D(h), \quad S_D = \{h \in \mathcal{K}_D : F_D(h) = F_D^*\}.$$

应先检查 $\mathcal{K}_D$ 是否非空、 F_D^* 是否有限, 再判断 S_D 是否非空及是否只有一个元素。 F_D^* 是值, S_D 是集合, 都不是某次算法运行的输出。参数化以后得到 $f_D = F_D \circ \Phi : \Theta \rightarrow \mathbb{R}$, 在可行参数集合 $\Theta_D = \Phi^{-1}(\mathcal{K}_D)$ 上求极小值; 参数解与函数解也须通过 Φ 联系。

选择优化规则以后, 才出现训练序列。令 $\mathbf{V}$ 为训练状态空间, 状态包含参数及动量等辅助量, $\text{out} : \mathbf{V} \rightarrow \mathcal{H}$ 为候选读出映射。更新算子与它生成的状态写为

$$\begin{aligned} T_{D,k} : \mathbf{V} \times \mathbf{U}_k &\rightarrow \mathbf{V}, \\ v_D^{(k+1)} &= T_{D,k}(v_D^{(k)}, U_k), \\ h_D^{(k)} &= \text{out}(v_D^{(k)}) = A^{(k)}(D, U). \end{aligned} \quad (17.10)$$

这里 U 包含初值及各步所用的随机数; 固定 U 后得到一条确定序列 $(v_D^{(k)})_{k \geq 0} \in \mathbf{V}^{\mathbb{N}_0}$ 。要判断算法是否逐步接近所求答案, 必须先说明想让哪个量收敛, 以及怎样衡量误差。例如, 令 $\mathcal{V}_D^* = \{v : \text{out}(v) \in S_D\}$, 在此集合非空时, 可以比较

$$\text{dist}(v_D^{(k)}, \mathcal{V}_D^*), \quad F_D(h_D^{(k)}) - F_D^*.$$

第一项使用状态空间的指定距离, $\text{dist}(v, B) = \inf_{b \in B} d_V(v, b)$; 第二项作为优化差距时要求当前输出可行且 F_D^* 有限。对可微无约束参数问题, 还可以用 $\|\nabla f_D(\theta^{(k)})\|$ 作为驻点残差。三种误差对应不同保证, 状态到最优集合的距离趋于零也不等于状态收敛到唯一一点。

随机更新还须声明是期望、依概率还是几乎处处收敛。同一数据可能有多个最优解; 当候选极限存在时, $(D, U) \mapsto h_D^{(\infty)} = \lim_k A^{(k)}(D, U)$ 是定义在这些输入上的极限选解映射。此时先验证算法极限是否属于最优解集合 S_D , 再问它为何选择其中某些解, 以及初始化和更新规则如何改变这一选择。这就是隐式选解分析要回答的问题。没有候选极限时, 不能凭参数范数或归一化方向存在极限, 就默认该选解映射也存在。

梯度估计、消息传播或隐藏状态求解还包含数值计算。令 $C : B \rightarrow C$ 表示要实现的计算映射, $\tilde{C}_b$ 为预算 b 下的实现, 则需要用 $d_C(\tilde{C}_b(x), C(x))$ 比较实际计算与精确计算的差异, 并计算所需的运算、存储、查询和通信成本。应规定允许输入 $x \in B$ 及误差标准; 实现含有随机性时, 计算误差也是随机变量。计算步数只是资源的一项。若 C 输出概率测度, 误差距离也应定义在测度空间上。

生成、检索和结构化解码常由多个计算阶段组成。将每个阶段写为 $C_j : B_{j-1} \rightarrow B_j$ 后, 整体计算是复合映射 $C_r \circ \dots \circ C_1$ 。除了分别检查表示、查询、评分与选择的误差, 还要检查前一阶段的误差会被后一阶段放大多少。

同时减少漏报和能耗时, 目标变成向量值映射 $F_D : \mathcal{K}_D \rightarrow \mathbb{R}^q$, q 为目标数。这时, 若候选 g 满足每个分量 $F_{D,j}(g) \leq F_{D,j}(h)$, 且至少一项严格变小, 就说明 g 在不增加其他代价的情况下改进了 h 。多目标分析据此寻找不能再作这种改进的候选。关心极端高温时, 可以另给风险泛函 $\rho : L \rightarrow \mathbb{R}$, 其中 L 是指定的一族损失随机变量, 研究 $h \mapsto \rho(\ell(h, Z))$ 。它的对象是随机损失的分布特征, 须明确选择哪一种尾部准则。若采用便于训练的代理目标, 则给出同一候选类上的两个泛函 $\tilde{R}, R : \mathcal{H} \rightarrow \mathbb{R}$, 比较 $\tilde{R}(h) - \inf_g \tilde{R}(g)$ 与 $R(h) - \inf_g R(g)$, 分析前者能否控制后者。

用验证结果选择正则权重, 或学习便于新任务适应的初始化, 会产生内外两层优化。令 $\eta \in \Lambda$ 表示可调整配置, 固定训练、验证记录 and 随机数, 则有限步内层输出与外层目标为

$$a_k : \Lambda \rightarrow H, \quad a_k(\eta) = A_\eta^{(k)}(D, U), \quad L_{\text{out}}(\eta) = \hat{R}_{D_{\text{va}}}(a_k(\eta)).$$

此时要研究外层目标 $L_{\text{out}} : \Lambda \rightarrow \mathbb{R}$ 怎样随配置变化, 以及内层训练没有充分求解时, 外层评分和选择会受到多大影响。若用理想内层解替代 a_k , 就应改写为集合值映射 $\eta \mapsto S(\eta)$; 只有给定唯一性或明确的选解规则, 才能继续把外层目标当作单值函数。

17.2.3 泛化与测试风险评估: 学习输出和总体风险的关系

模型可能记住温度记录中的噪声, 使训练损失很小而未来误差仍然很大。固定计算预算, 简记 $A = A^{(k)} : Z^n \times U \rightarrow \mathcal{H}$ 。当 $D \sim Q_n$ 、 $U \sim \nu$ 独立时, 学习输出是 $\mathcal{H}$ 值随机变量, 其概率律为 $A_\#(Q_n \otimes \nu) \in \mathcal{P}(\mathcal{H})$ 。泛化分析在这里评价的是算法用数据选出的候选。候选本身依赖训练数据, 因此, 不能直接套用抽样前已经固定某个候选时的估计结论。在同分布基准中, 两个主要随机量为

$$\begin{aligned} \Delta_{\text{gen}}(D, U) &= R_P(A(D, U)) - \hat{R}_D(A(D, U)), \\ \Delta_{\text{exc}}(D, U) &= R_P(A(D, U)) - \inf_{h \in \mathcal{H}_e} R_P(h). \end{aligned}$$

它们是定义在 $Z^n \times U$ 上的实值函数，分别表示泛化差与类内超额风险；后者作为与可行最优的比较时须注明输出可行、风险下确界有限。要求可以是对 $Q_n \otimes \nu$ 控制误差期望，或控制超过 ϵ 的概率，不能省略随机性来源。

与之相关的一致估计分析使用经验测度映射及损失函数集合

$$D \mapsto \hat{P}_D = \frac{1}{n} \sum_{i=1}^n \delta_{Z_i} \in \mathcal{P}(Z), \quad \mathcal{F}_\ell = \{z \mapsto \ell(h, z) : h \in \mathcal{H}_c\}.$$

比较量是随机变量 $\sup_{f \in \mathcal{F}_\ell} |\int f d\hat{P}_D - \int f dP|$ 。这个上确界同时约束类中每个函数的估计误差。因此，即使算法根据数据选出候选，所选候选也不会超出这个共同误差界。独立、连续相关和按历史选择记录的机制对应不同 Q_n ；仅对固定 f 的估计保证不能直接代替这个共同界。

独立测试则在训练及配置选择完成后固定 h ，另取与全部训练和验证信息独立的 $D_{te} \sim P_{te}^{\otimes m}$ 。此时接受统计分析的对象是估计映射

$$\hat{r}_{h,m} : Z^m \rightarrow \mathbb{R}, \quad \hat{r}_{h,m}(D_{te}) = \frac{1}{m} \sum_{i=1}^m \ell(h, Z_i^{te}),$$

其目标实数为 $R_{P_{te}}(h)$ 。置信区间是另一个映射 $I_{h,m} : Z^m \rightarrow 2^{\mathbb{R}}$ ，输出一个区间，所求覆盖要求为 $P\{R_{P_{te}}(h) \in I_{h,m}(D_{te})\} \geq 1 - \delta$ 。这里的概率只对新测试样本取得；若 h 由训练与验证信息选出，可以先条件于这些信息。

若要求在一族任务上都能学习，则分析对象变成规则族。令 $\mathcal{P}_0 \subseteq \mathcal{P}(Z)$ 为允许分布集合， $\mathfrak{A}$ 为允许的可行输出规则序列 $(A_n)_{n \geq 1}$ 组成的集合。可学习性进一步问：能否找到同一套规则 $(A_n) \in \mathfrak{A}$ ，使对每个 $\epsilon > 0$ 、 $\delta \in (0, 1)$ ，从某个 $n_0(\epsilon, \delta)$ 起都有

$$\sup_{P \in \mathcal{P}_0} \mathbb{P}_{P^{\otimes n} \otimes \nu} \{\Delta_{exc}(D, U) > \epsilon\} \leq \delta.$$

此处 Δ_{exc} 用相应的 A_n 计算，并要求各 P 下的风险下确界有限。同一个规则族必须服务于全部允许的 P ，而不是知道真实 P 后才另选规则。可计算性与计算复杂度还要求说明 A_n 的实现与资源；一次测试成绩不能回答这些存在性问题。

模型给出概率分布时，还要问清楚随机抽取的是什么。条件预测在给定输入后对标签赋概率，是概率核 $q_D : X \times \Sigma_Y \rightarrow [0, 1]$ ；随机预测器是完整函数上的测度 $\rho_D \in \mathcal{P}(\mathcal{H})$ ，其平均风险为 $\int R_P(h) \rho_D(dh)$ 。用神经元分布表示网络时，则给定特征 $\varphi : X \times \Omega \rightarrow \mathbb{R}$ 、 $\lambda_D \in \mathcal{P}(\Omega)$ ，先构造确定函数 $h_D(x) = \int \varphi(x, \omega) \lambda_D(d\omega)$ ，再计算 $R_P(h_D)$ 。这三种对象分别是条件核、函数空间上的测度、表示单位空间上的测度，风险不能互换。

反复调参或满意即停的验证集评估，还包含选择与停止规则。令 $\mathcal{F}_m^{va}$ 为训练信息、已用算法随机数及截至第 m 步可见验证信息生成的 σ 代数，候

选 $\tilde{h}_m$ 必须对它可测, 停止轮次 τ 满足 $\{\tau \leq m\} \in \mathcal{F}_m^{\text{va}}$ 。为了保证反复查看验证结果以后, 报告的区间仍有声明的置信度, 需要一起分析整个随机序列 $(\tilde{h}_m, I_m)_{m \geq 1}$ 及停止规则, 例如研究事件 $\{R_{P_{\text{va}}}(\tilde{h}_m) \in I_m \text{ 对所有 } m\}$ 的概率。若又根据测试结果选择模型或决定停止时点, 须在测试信息上作同样的联合选择与停止分析, 已不能按固定候选的独立测试处理。分层审计、成组数据、成对方法比较和多次检验均应保留实际联合律, 不能直接套用固定候选的独立测试区间。

17.2.4 预测与发布: 可靠性、测试鲁棒性和发布要求

预测器给出一个温度区间, 我们会关心真实温度有多大概率落在其中; 给出越限概率 0.1, 我们会关心这类预测对应的实际越限频率是否接近 0.1。这些要求比平均预测误差小更具体。固定训练结果后, 预测集合是集合值映射 $C_D: \mathbf{X} \rightarrow 2^Y$, 二元越限概率预测器是函数 $p_D: \mathbf{X} \rightarrow [0, 1]$ 。为了判断这些概率声明是否可靠, 给定测试分布 $(X, Y) \sim P_{\text{te}}$, 需要研究

$$P_{\text{te}}\{(x, y) : y \in C_D(x)\}, \quad \mathbb{E}_{P_{\text{te}}}[Y | p_D(X)] - p_D(X).$$

第一项是覆盖事件的概率, 要求该事件可测; 第二项是校准残差随机变量, 此处 $Y \in \{0, 1\}$ 。其为零是几乎处处意义的等式。若还对训练样本取平均, 就应改用训练记录、算法随机数和新记录的联合律。按群体限制错误率时, 进一步给出 (X, Y, G_{grp}) 的联合律。对二元报警函数 h , 群体 g 的漏报率是泛函 $\text{FNR}_g(h) = \mathbb{P}\{h(X) = 0 \mid Y = 1, G_{\text{grp}} = g\}$ 。条件事件须有正概率。给定上限 b_g 后, 可行集为 $\{h : \text{FNR}_g(h) \leq b_g \text{ 对所有规定群体 } g\}$, 还需分析它是否非空。

传感器噪声可能改变固定模型的报警决定。给定 $h_D: \mathbf{X} \rightarrow Y$ 、允许扰动的集合值映射 $\mathcal{U}: \mathbf{X} \rightarrow 2^{\mathbf{X}}$ 及输出距离 d_Y , 为了判断测量变化会把预测改变多少, 需要比较

$$\omega_{h_D}(x) = \sup_{x' \in \mathcal{U}(x)} d_Y(h_D(x'), h_D(x)).$$

若标签 y 在允许范围内仍有效, 还可以研究 $\sup_{x' \in \mathcal{U}(x)} \ell(h_D, (x', y))$ 。这里变化的是 x , 模型保持固定; 对抗攻击还须把攻击者可见的信息、可改字段与预算写入允许集合或策略。

改变整个工况频率时, 则给定测度集合 $\mathcal{Q} \subseteq \mathcal{P}(Z)$, 研究固定候选上的泛函 $Q \mapsto R_Q(h_D)$ 及 $\sup_{Q \in \mathcal{Q}} R_Q(h_D)$ 。一般分布变化不一定等于小输入扰动, 还可能改变标签规律。若训练时就选择候选以减小这一最坏风险, 数学对象进一步变为

$$F_{\text{rob}}: \mathcal{H}_{\mathcal{C}} \rightarrow \mathbb{R}, \quad F_{\text{rob}}(h) = \sup_{Q \in \mathcal{Q}} R_Q(h),$$

此处假定上确界有限。接着最小化 F_{rob} ，就是为最不利分布选择模型：内层寻找最不利分布，外层选择候选；它与固定模型的扰动分析有不同变量。

发布模型的隐私要求研究随机机制，而非一个固定预测函数。给定发布空间 $\mathbf{W}$ 、机制 $M : \mathbf{Z}^n \times \mathbf{U} \rightarrow \mathbf{W}$ 以及数据相邻关系 $D \sim D'$ ，固定数据后诱导的输出律为

$$\Lambda_D = M(D, \cdot)_{\#} \nu \in \mathcal{P}(\mathbf{W}).$$

隐私要求限制的是：只改变受保护的数据单位时，观察者看到的发布结果会有多大变化。因此，要对每对相邻 D, D' 以及每个可测发布事件 $B \subseteq \mathbf{W}$ ，比较 $\Lambda_D(B)$ 与 $\Lambda_{D'}(B)$ ，并规定允许的概率差或似然比界。数据在这里固定，概率来自机制随机性。遗忘机制是从原发布结果、允许保留的数据、删除索引和新随机数到发布空间 $\mathbf{W}$ 的映射。例如，允许访问原数据时可写为 $\mathcal{U} : \mathbf{W} \times \mathbf{Z}^n \times \{1, \dots, n\} \times \mathbf{U}' \rightarrow \mathbf{W}$ ，其输出为 $\tilde{M}_{D_{-i}} = \mathcal{U}(M(D, U), D, i, U')$ ；限制数据访问时须相应修改输入。为了判断删除操作是否接近“删掉记录后重新训练”的效果，需要比较 $d_{\mathcal{P}}(\text{Law}(\tilde{M}_{D_{-i}}), \Lambda_{D_{-i}})$ ，其中 D_{-i} 是删除第 i 条记录后的数据， $\Lambda_{D_{-i}}$ 由对应样本数的重训机制生成， $d_{\mathcal{P}}$ 是预先选定的输出测度距离。

解释模型行为也须先指定输出对象。以简单函数 g 解释 h_D 时，行为忠实性比较 $d_H(g, h_D)$ ；输入归因则另给规则 $\alpha_{h_D} : \mathbf{X} \rightarrow \mathbb{R}^d$ ，输出 d 个特征的贡献数值，并分析该规则对输入、基线或补全约定的响应。若这些数值被解释为现实干预的后果，还须给出环境目标映射 J 并回到可识别性分析。函数响应本身不能替代干预目标的识别条件。

17.2.5 学习配置的改变：比较解、轨迹与输出

纠正标签、更换优化器或提高漏报代价，都要求比较两次设定中的结果。这里两种配置既可实际前后运行，也可是假设性的对照。用 $\eta \in \Lambda$ 收集本次允许改变的量，例如 $(\mathcal{M}, D)$ 中的指定分量；未列入 η 的条件保持固定。在共同候选空间 $\mathbf{H}$ 中，每个配置给出泛函 F_{η} 、可行集合 $\mathcal{K}_{\eta}$ 和相应求解规则。问题改变以后，可能关心三个不同结果：理想最优解、计算到第 k 步的状态，以及算法实际输出的候选。它们分别由以下映射给出：

$$\begin{aligned} S : \Lambda \rightarrow 2^{\mathbf{H}}, \quad S(\eta) &= \arg \min_{h \in \mathcal{K}_{\eta}} F_{\eta}(h), \\ V_k : \Lambda \times \mathbf{U} \rightarrow \mathbf{V}, \quad V_k(\eta, U) &= v_{\eta}^{(k)}, \\ H_k : \Lambda \times \mathbf{U} \rightarrow \mathbf{H}, \quad H_k(\eta, U) &= \text{out}_{\eta}(v_{\eta}^{(k)}). \end{aligned} \tag{17.11}$$

S 是集合值映射， V_k 输出第 k 步状态， H_k 输出有限步候选。若 $\eta = (\mathcal{M}, D)$ ， $H_k(\eta, U)$ 就是设定 $\mathcal{M}$ 所规定的 $A^{(k)}(D, U)$ 。写出共同状态空间 $\mathbf{V}$ 的前提是两次状态可以比较；架构改变维数时，应先规定到共同空间的表示，或只通过 H_k 在共同函数空间比较。

设备进入新工况、更换传感器、只收集报警时段记录、纠正已取得的标签, 分别作用于 μ 、 K 、 Γ_n 和 D 。这些变化进入训练之前还经过确定的分布映射

$$(\mu, K) \mapsto P = \mu K, \quad (\mathcal{E}, \mathcal{O}, \Gamma_n) \mapsto Q_n = \Gamma_n(\mathcal{E}, \mathcal{O}).$$

前者输出单条记录的概率测度, 后者输出 Z^n 上的联合测度。数据生成规律改变以后, 应先明确 D, D' 的联合抽样方式, 再比较训练结果; 直接修改一批已实现记录时, 可以固定 D, D' 及算法随机数作确定性比较。

例如, 只把一条温度标签改为极大值时, 固定其余配置和共同随机数 U , 可分别比较

$$\begin{aligned} d_{\text{set}}(S(\eta'), S(\eta)), \\ e_k = d_V(V_k(\eta', U), V_k(\eta, U)), \\ d_H(H_k(\eta', U), H_k(\eta, U)). \end{aligned}$$

第一项需要选定解集合的距离; 若采用 Hausdorff 距离, 可先限定为非空紧解集, 解集消失则另外作为可行性问题分析。第二项研究整段序列 $(e_k)_k$ 的增长或衰减, 第三项研究给定预算下的输出。随机比较须说明是共用随机数、采用其他耦合, 还是直接比较两种输出律。把 D' 限制在允许污染集合内并对这些距离或风险增量取上确界, 就得到相应的训练鲁棒性问题。

错误数据与更换优化器都能改变 $T_{D,k}$, 因而都可进入序列扰动分析。提高漏报代价、增加误报约束则先改变 F_η 与 $\mathcal{K}_\eta$, 随后影响解与求解过程。比较预测后果时, 应选共同评价泛函, 例如固定损失 ℓ 和干净分布 P 后比较 $R_P(H_k(\eta', U)) - R_P(H_k(\eta, U))$, 也可以比较同一输入上的报警决定。不同含义的训练损失数值不能直接充当这个共同指标。

若两次评价总体也改变, 令 $h = H_k(\eta, U)$ 、 $h' = H_k(\eta', U)$, 在相同损失下有

$$\begin{aligned} R_{P'}(h') - R_P(h) &= [R_P(h') - R_P(h)] \\ &\quad + [R_{P'}(h') - R_P(h')]. \end{aligned}$$

第一项使用同一个评价总体 P , 比较两个模型 h' 与 h ; 第二项固定新模型 h' , 只改变评价总体。这样才能区分模型改变与评价总体改变的贡献。本小节比较两种学习配置下的结果; 下一小节则在一次任务内部, 研究训练信息怎样支持不同分布上的目标评价。例如, 旧数据能否评价新工况, 是来源与目标的联系问题; 加入新工况数据后模型改变多少, 是配置比较问题。一次迁移任务可以同时需要这两种分析。

17.2.6 来源与目标的联系: 跨分布学习与策略反馈

用普通负载记录训练, 却要求在高负载工况中准确, 训练和评价从一开始就面向不同总体。在共同记录空间中, 令 $P_s, P_t \in \mathcal{P}(Z)$ 分别为来源、目标

律, 以 $\mathfrak{R} \subseteq \mathcal{P}(\mathcal{Z}) \times \mathcal{P}(\mathcal{Z})$ 规定允许的来源与目标关系。先考虑只有独立来源样本 $D \sim P_s^{\otimes n}$ 的设定。此时需要分析的两个映射是

$$\begin{aligned} \Xi_s : \mathfrak{R} &\rightarrow \mathcal{P}(\mathcal{Z}), \quad (P_s, P_t) \mapsto P_s, \\ J_t : \mathfrak{R} &\rightarrow \mathbb{R}^{\mathcal{H}_e}, \quad (P_s, P_t) \mapsto R_{P_t}. \end{aligned} \quad (17.12)$$

$\mathbb{R}^{\mathcal{H}_e}$ 表示以候选为输入的实值泛函集合。 Ξ_s 输出可观测来源律, J_t 输出整个目标风险泛函。要判断来源记录能否支持目标评价, 先检查 $\mathfrak{R}$ 中相同的来源分布是否必然对应相同的目标风险。如果相同来源律可以对应不同目标风险, 来源信息就不能唯一确定整个目标风险泛函。不过, 选出好决策未必需要知道全部风险数值: 不同目标风险仍可能具有共同的最优候选。若只要求学习决策, 就应进一步检查这些目标是否允许共同的最优或近优候选。

扩展到一般来源样本律 $Q_{s,n}$ 时, 识别条件应针对实际可观测的联合律陈述。目标风险估计器是 $\hat{\mathcal{R}}_n : \mathcal{Z}^n \rightarrow \mathbb{R}^{\mathcal{H}_e}$ 。来源记录能够确定目标风险以后, 再问有限记录能估计多准, 即比较

$$\sup_{h \in \mathcal{H}_e} |\hat{\mathcal{R}}_n(D)(h) - R_{P_t}(h)|, \quad D \sim Q_{s,n}.$$

学习映射 A 再利用 D 选取候选, 其目标超额风险是 $R_{P_t}(A(D, U)) - \inf_{h \in \mathcal{H}_e} R_{P_t}(h)$ 。若另有目标侧样本或已知密度比, 应把这些信息加入观测映射与估计器输入, 重新陈述识别与估计问题。同一总体的两批有限样本不同只是抽样波动; 两个总体之间的关系则是问题的额外组成。

训练收敛仍由式 (17.10) 中的算子与序列决定。固定 D 、 $T_{D,k}$ 、初值和随机数, 只改变用于评价的 P_t , $v_D^{(k)}$ 不会改变; 变化的是 $R_{P_t}(h_D^{(k)})$ 。重加权、微调或补充数据才会改变 F_D 、 $T_{D,k}$ 或 A 。采用这些适应方法时, 既要分析来源信息是否支持目标风险, 也要用上一小节的映射比较新旧训练结果。

除了直接用来源记录估计目标风险, 还可以先从来源任务学到表示或参数, 再用它们帮助目标任务。迁移学习 (transfer learning) 需要说明这些共享信息如何进入目标学习过程。令来源记录空间为 $\mathcal{Z}_s$ 、目标记录空间为 $\mathcal{Z}_t$, 共享信息空间为 $\mathcal{I}$ 。来源信息提取与目标学习是两个可测映射

$$\begin{aligned} B_s : \mathcal{Z}_s^{n_s} \times \mathcal{U}_s &\rightarrow \mathcal{I}, \quad I_s = B_s(D_s, U_s), \\ A_{tr} : \mathcal{Z}_t^{n_t} \times \mathcal{I} \times \mathcal{U}_t &\rightarrow \mathcal{H}_t, \quad h_{tr} = A_{tr}(D_t, I_s, U_t). \end{aligned}$$

不使用来源信息的规则为 $A_0 : \mathcal{Z}_t^{n_t} \times \mathcal{U}_t \rightarrow \mathcal{H}_t$, 令 $h_0 = A_0(D_t, U_t)$ 。共享信息是否有帮助, 要在同一个目标任务上比较 $R_t(h_{tr}) - R_t(h_0)$ 。为使比较有明确含义, 还须规定双方的数据和计算预算, 以及上述随机量的联合分布。输入频率改变与给定输入后的标签规律改变, 是 $\mathfrak{R}$ 的不同限制; 若输出空间或损失也改变, 则由 $\mathcal{H}_t$ 与 R_t 重新定义目标任务。

少样本学习需要说明少量样本何以足够, 例如采用了什么结构假设; 若利用额外信息 I_s , 还须交代其来源。元学习则把适应映射 $a: \mathbf{Z}^m \rightarrow \mathcal{H}$ 作为候选; 在共同记录与候选空间的简化设定中, 以 $\vartheta \in \mathbf{T}_{\text{task}}$ 索引任务, 每项任务给定样本律 Q_m^ϑ 和风险泛函 R_ϑ 。任务索引服从分布 $\zeta \in \mathcal{P}(\mathbf{T}_{\text{task}})$, 外层目标为

$$R_{\text{meta}}(a) = \mathbb{E}_{\vartheta \sim \zeta} \mathbb{E}_{D \sim Q_m^\vartheta} R_\vartheta(a(D)).$$

这里学习的是收到少量新记录后怎样适应的规则。评价这条规则时, 数据分为抽取任务和抽取任务内记录两个层次; 任务数和每个任务内的样本数不能合并成一个独立样本量。

强化学习还增加策略对数据的反馈。令 Π 为可得历史到行动的策略核族, $\mathbf{T}_H$ 为第 17.1.5 节定义的长度 H 的理论轨迹空间, $b: \mathbf{T}_H \rightarrow \mathbf{Z}_{\text{rec}}$ 为保留实际可采集字段的可测记录映射。固定行为策略 $\beta \in \Pi$ 和目标策略 $\pi \in \Pi$, 对允许的动态环境集合 $\mathfrak{G}_{\text{dyn}}$, 定义

$$\begin{aligned} \Xi_\beta: \mathfrak{G}_{\text{dyn}} &\rightarrow \mathcal{P}(\mathbf{Z}_{\text{rec}}), \quad \Xi_\beta(\mathcal{E}) = b_\# P_\mathcal{E}^\beta, \\ J_\pi: \mathfrak{G}_{\text{dyn}} &\rightarrow \mathbb{R}, \quad J_\pi(\mathcal{E}) = \int \ell(\pi, \tau) P_\mathcal{E}^\pi(d\tau). \end{aligned} \quad (17.13)$$

ℓ 是指定的可积累计损失。我们只有旧策略 β 采集的记录, 却想知道新策略 π 执行后的成本。这就是离策略评价 (off-policy evaluation) 的问题: 先检查旧记录的分布 Ξ_β 能否确定目标成本 J_π , 再用估计映射 $\hat{J}_{\pi, n}: \mathbf{Z}_{\text{rec}}^n \rightarrow \mathbb{R}$ 估计它。样本律由采集方式给出, 只有独立采集完整运行记录时才可取 $\Xi_\beta(\mathcal{E})^{\otimes n}$ 。即使环境不变, $P_\mathcal{E}^\beta$ 与 $P_\mathcal{E}^\pi$ 也可不同; 实际记录还可能隐藏状态, 不能把理论轨迹直接当成全部可见数据。

离线强化学习 (offline reinforcement learning) 进一步使用 $A_{\text{off}}: \mathbf{Z}_{\text{rec}}^n \times \mathbf{U} \rightarrow \Pi$ 从固定记录选择 $\pi_D = A_{\text{off}}(D, U)$ 。固定环境后, 风险泛函为 $R_t: \Pi \rightarrow \mathbb{R}$, $R_t(\pi) = J_\pi(\mathcal{E})$, 选择是否成功, 可以用目标成本 $R_t(\pi_D)$ 超过允许策略中最低成本的部分, 即 $R_t(\pi_D) - \inf_{\pi \in \Pi} R_t(\pi)$ 衡量。这里每个候选 π 都有自己的积分测度 $P_\mathcal{E}^\pi$, 目标律不是与候选无关的常量。若行为策略从未执行某种散热动作, 相应效果可能无法识别; 评价一个预先固定的策略与从许多策略中选择一个, 也需要不同的统计保证^{1,2}。

在线交互时, 把已见记录、训练状态和已用随机数合入可得历史 $\mathcal{H}_t \in \mathbf{I}_t^{\text{on}}$, 其中 $\mathbf{I}_t^{\text{on}}$ 是第 t 轮的历史空间, v_t 包含更新所需的记忆。行动核 $\beta_t(da | \mathcal{H}_t)$ 、环境转移核 T 、观测核 K_o , 与状态更新映射 $\mathcal{T}_t: \mathbf{V} \times \mathbf{Z} \times \mathbf{U}_t \rightarrow \mathbf{V}$ 共同规定递推 $v_{t+1} = \mathcal{T}_t(v_t, Z_{t+1}, U_t)$ 和联合历史律

$$\mathbb{P}^{\text{on}} = \text{Law}\left((s_t, \mathcal{H}_t, v_t)_{t=0}^H \in \mathcal{P}\left(\prod_{t=0}^H (S \times \mathbf{I}_t^{\text{on}} \times \mathbf{V})\right)\right).$$

¹ R. S. Sutton, A. G. Barto, *Reinforcement Learning: An Introduction*, MIT Press, 2018, 2nd ed.

² S. Levine, A. Kumar, G. Tucker, J. Fu, *Offline Reinforcement Learning: Tutorial, Review, and Perspectives on Open Problems* In arXiv preprint arXiv:2005.01643, 2020

此处 Z 是单步更新记录空间, Z_{t+1} 表示新取得的记录。由于下一条记录取决于已有历史, 统计分析必须在这个联合分布下研究条件均值、累计损失和估计误差。如果关心训练状态是否收敛或能否跟随变化的目标, 则研究更新序列 $(v_t)_t$ 。设备的闭环安全则针对另一事件, 例如给定安全状态集合 $S_{\text{safe}} \subseteq S$ 后, 研究 $\mathbb{P}^{\text{on}}\{s_t \in S_{\text{safe}} \text{ 对所有 } t \leq H\}$ 。训练状态 v_t 与物理状态 s_t 的稳定性因此不能混为一谈。

设备老化使任务随轮次变化时, 持续学习 (continual learning) 要同时吸收新信息和保留旧能力。令 h_t 是取得本轮反馈前按历史选出的候选, $f_t : \mathcal{H} \rightarrow \mathbb{R}$ 是第 t 轮损失, $\mathcal{K}_N \subseteq \mathcal{H}^N$ 是预先规定的比较序列集合。此时需要研究候选如何跟随变化的任务, 并将它的总损失与允许的比较序列相比:

$$\sum_{t=1}^N f_t(h_t) - \inf_{(g_1, \dots, g_N) \in \mathcal{K}_N} \sum_{t=1}^N f_t(g_t).$$

反馈时序与 $\mathcal{K}_N$ 中允许的变化预算, 决定此量的含义。旧任务 j 的保持另由固定泛函 $R_j : \mathcal{H} \rightarrow \mathbb{R}$ 衡量, 例如比较学习新任务后的 $R_j(h_t) - R_j(h_j)$, 其中 h_j 是完成旧任务时的参照候选。这些量都不能由最终参数是否存在极限来替代。

主动选择负载试验或请求人工复核时, 令 (Q, Σ_Q) 为查询空间, $\alpha_t : \mathcal{I}_t^{\text{on}} \times \Sigma_Q \rightarrow [0, 1]$ 为查询概率核, 查询后的记录服从明确的条件观测核 $K_{\text{qry}}(\text{dz} \mid \mathcal{E}, q_t, \mathcal{H}_t)$ 。它们诱导查询与记录的联合律 $\mathbb{P}_{\mathcal{E}}^{\alpha}$ 。查询策略 $\alpha = (\alpha_t)_t$ 决定花费预算取得哪些证据。为了判断这种选择是否有用, 例如可以在预算约束 $\mathbb{E}_{\mathbb{P}_{\mathcal{E}}^{\alpha}} \sum_t c(q_t) \leq B$ 下最小化 $\mathbb{E}_{\mathbb{P}_{\mathcal{E}}^{\alpha}} R_{\mathcal{E}}(h_N)$, 其中 $c : Q \rightarrow [0, \infty)$ 为查询代价, B 为预算。信息量准则则需另给目标不确定性的概率模型; 查询次数本身不能代表取得的信息量。

多个设备竞争冷却资源时, 数学对象是联合策略集合 $\Pi = \prod_{i=1}^m \Pi_i$ 与各方成本泛函 $J_i : \Pi \rightarrow \mathbb{R}$ 。各方目标不同, 要问是否存在一组相容的策略 $\pi \in \Pi$, 使任何一方单独改变策略都不能降低自己的成本: $J_i(\pi) \leq J_i(\pi'_i, \pi_{-i})$; 允许信息与偏离范围是定义的一部分。给定响应算子后产生的联合策略序列, 则另作收敛分析。

表 17.2 把上述任务整理为机器学习问题与数学问题的对应。表中沿用前面的训练、验证和测试分工; 测试风险始终针对任务指定的评价分布, 独立性和同分布仍须由各任务的采样假设给出。强化学习使用训练轨迹样本, 行为策略负责采集这些样本, 目标策略是所要评价或学习的策略; 二者各自诱导轨迹分布。

一个机器学习问题通常需要多条数学路线。例如, 泛化与测试风险评估既需要分析经验积分的误差, 也需要分析训练样本选出的随机模型, 因而在同一任务下分别列出概率测度和学习映射上的问题。训练鲁棒性则分别研究理想解、训练轨迹与有限步学习输出, 不把三者另列为三项机器学习

任务。要研究什么对象，取决于最后想知道哪个结果。例如，训练样本虽是变化的来源，如果想知道算法每一步会偏离多少，就应研究训练序列；如果想知道报警决定如何改变，就应研究最终预测函数。对象名称、数学问题名称和问题编号均与第 17.3 节的数学表对应。对象列中的公式列出相应任务使用的代表对象，具体定义与比较量见各小节。

机器学习问题	数学对象	数学问题
目标可识别性与统计恢复 训练信息能否识别目标，有限训练样本能否恢复目标？	观测核、概率测度与经验测度 Ξ, J 学习映射与随机输出律 $\hat{J}_n, J$	目标的可识别性（问题 17.1） 观测等价是否留下目标歧义 统计恢复与一致性（问题 17.20） 有限样本的恢复误差与一致性
模型表达与逼近 候选模型能否表示或逼近目标函数，或压缩已有模型？	候选函数、函数类与表示映射 $h, \mathcal{H}, \Phi$	精确表示与最佳逼近（问题 17.7） 目标函数或参考模型的最佳逼近误差
表示学习与结构约束 表示是否保留任务信息并满足不变性或等变性？	候选函数、函数类与表示映射 $h, \mathcal{H}, \Phi$	精确表示与最佳逼近（问题 17.7） 结构约束下的候选范围与逼近误差 对称结构与信息保留（问题 17.9） 群作用关系及任务函数的因子化
概率推断与生成 条件概率、隐变量推断或生成样本是否准确？	观测核、概率测度与经验测度 $Q_h, Q_h(\cdot x)$ 目标泛函、可行集与解集映射 $F, \mathcal{K}, S$ 计算算子与迭代序列 $C, T_{D,k}, (v^{(k)})_k$	条件化、积分与生成（问题 17.6） 给定模型的条件分布与积分 可行性、极值存在与最优条件（问题 17.10） 采用变分近似时的目标与最优解 计算正确性、近似误差与资源（问题 17.15） 消元、近似及多阶段推断的误差与资源 不变律、分布极限与积分误差（问题 17.17） 迭代采样的分布极限与积分误差
训练求解与收敛 经验训练问题有无合格解，算法能否在预算内求得？	目标泛函、可行集与解集映射 $F, \mathcal{K}, S$ 计算算子与迭代序列 $C, T_{D,k}, (v^{(k)})_k$	可行性、极值存在与最优条件（问题 17.10） 理想解的存在、唯一性与最优条件 计算正确性、近似误差与资源（问题 17.15） 训练计算的正确性、近似精度与资源 极限、选解与收敛速度（问题 17.16） 实际迭代的极限、选解与收敛速度
代理损失的任务有效性 代理风险接近最优能否控制任务超额风险？	目标泛函、可行集与解集映射 $F, \mathcal{K}, S$	代理目标与任务目标的关系（问题 17.11） 代理超额风险与任务超额风险的联系

续下页

表 17.2 (续)

机器学习问题	数学对象	数学问题
多目标与尾部风险优化 多个任务指标、尾部风险和约束能否兼顾?	观测核、概率测度与经验测度 P_{te}, p_D, C_D 目标泛函、可行集与解集映射 $F, \mathcal{K}, S$	覆盖、校准与条件风险 (问题 17.5) 要求涉及覆盖、校准或群体条件时的测试验证 可行性、极值存在与最优条件 (问题 17.10) 给定损失及约束后的可行性与最优解 多目标、尾部风险与取舍 (问题 17.13) Pareto 取舍与所选风险泛函
模型选择与超参数优化 如何利用验证集选择模型和训练配置?	候选函数、函数类与表示映射 $h, \mathcal{H}, \Phi$ 目标泛函、可行集与解集映射 $F, \mathcal{K}, S$ 计算算子与迭代序列 $C, T_{D,k}, (v^{(k)})_k$ 学习映射与随机输出律 $\hat{J}_n, A, \Lambda_D$	精确表示与最佳逼近 (问题 17.7) 候选类变更时的表达范围 最优值与解集的敏感性 (问题 17.12) 目标、约束或候选类改变时的理想解响应 内外层优化及内层误差 (问题 17.14) 内层训练与验证样本上的外层选择 计算正确性、近似误差与资源 (问题 17.15) 共同精度下的运算、存储与查询预算 极限、选解与收敛速度 (问题 17.16) 不同更新规则的精度、速度与选解 数据依赖输出的泛化与超额风险 (问题 17.21) 配置选择后候选的测试风险 重新学习后的预测与风险响应 (问题 17.23) 共同预算下有限步候选的行为比较
泛化与测试风险评估 有限样本能否支持训练所得模型的测试风险保证与估计?	观测核、概率测度与经验测度 $P, \hat{P}_D, Q_n$ 学习映射与随机输出律 $\hat{J}_n, A, \Lambda_D$	经验积分的一致估计 (问题 17.2) 指定采样机制相对测试分布的经验误差; 固定模型的独立测试是特例 数据依赖输出的泛化与超额风险 (问题 17.21) 训练样本及验证选择后的泛化差与超额测试风险
可学习性与样本复杂度 给定任务族是否存在统一有效的学习规则?	观测核、概率测度与经验测度 $P, \hat{P}_D, Q_n$ 学习映射与随机输出律 $\hat{J}_n, A, \Lambda_D$	经验积分的一致估计 (问题 17.2) 候选类上的共同误差与样本量 统一学习规则的存在与复杂度 (问题 17.22) 学习规则的存在、信息下界与实现成本
预测可靠性与公平性验证 测试分布上的覆盖、校准和群体指标是否符合要求?	观测核、概率测度与经验测度 P_{te}, p_D, C_D 目标泛函、可行集与解集映射 $F, \mathcal{K}, S$	覆盖、校准与条件风险 (问题 17.5) 规定联合律上的覆盖事件、校准与条件率 可行性、极值存在与最优条件 (问题 17.10) 要求纳入训练约束时, 可行候选是否存在 多目标、尾部风险与取舍 (问题 17.13) 要求纳入训练约束时, 联合约束与指标取舍

续下页

表 17.2 (续)

机器学习问题	数学对象	数学问题
测试鲁棒性与对抗防御 测试输入或测试分布变化后, 预测与测试风险是否受控?	观测核、概率测度与经验测度 P, P', Q_n, Q'_n 候选函数、函数类与表示映射 $h, \mathcal{H}, \Phi$ 目标泛函、可行集与解集映射 $F, \mathcal{K}, S$ 计算算子与迭代序列 $C, T_{D,k}, (v^{(k)})_k$	观测律与风险积分的扰动 (问题 17.4) 固定模型的测试风险随测试分布变化 固定函数的输入响应与分布风险 (问题 17.8) 固定模型对测试输入及攻击的最坏响应 可行性、极值存在与最优条件 (问题 17.10) 采用对抗训练或分布鲁棒优化时的目标求解 计算正确性、近似误差与资源 (问题 17.15) 内层攻击搜索与最坏风险计算的误差
训练鲁棒性 替换、污染或投毒训练样本后, 学习结果是否稳定?	目标泛函、可行集与解集映射 $F, \mathcal{K}, S$ 计算算子与迭代序列 $C, T_{D,k}, (v^{(k)})_k$ 学习映射与随机输出律 $\hat{J}_n, A, \Lambda_D$	最优值与解集的敏感性 (问题 17.12) 理想最优值与解集的变化 数据或更新改变后的轨迹响应 (问题 17.18) 中间训练轨迹的误差传播 重新学习后的预测与风险响应 (问题 17.23) 有限步输出、预测及共同测试风险的变化
训练目标与约束变更 改变损失函数、正则项或约束 后, 学习结果怎样变化?	目标泛函、可行集与解集映射 $F, \mathcal{K}, S$ 学习映射与随机输出律 $\hat{J}_n, A, \Lambda_D$	最优值与解集的敏感性 (问题 17.12) 可行集、最优值、活动约束与解分支 重新学习后的预测与风险响应 (问题 17.23) 重训后预测与共同测试指标的变化
模型解释与输入归因 解释是否忠实, 归因是否稳定, 能否支持因果声明?	观测核、概率测度与经验测度 Ξ, J 候选函数、函数类与表示映射 $h, \mathcal{H}, \Phi$	目标的可识别性 (问题 17.1) 观测信息是否识别所声称的干预目标 精确表示与最佳逼近 (问题 17.7) 解释函数对固定模型的行为逼近 固定函数的输入响应与分布风险 (问题 17.8) 固定归因规则对输入的响应
隐私保护 发布训练结果是否泄露单个训练 样本的信息?	学习映射与随机输出律 M, Λ_D	发布与遗忘输出的可区分程度 (问题 17.24) 相邻训练集诱导的随机发布概率比较
机器遗忘 删除训练样本后的结果能否接 近删除后重训并保留所需能力?	学习映射与随机输出律 $\hat{J}_n, A, \Lambda_D$	重新学习后的预测与风险响应 (问题 17.23) 删除后候选在共同测试任务上的行为 发布与遗忘输出的可区分程度 (问题 17.24) 遗忘输出律与删除后重训输出律

续下页

表 17.2 (续)

机器学习问题	数学对象	数学问题
迁移学习与域适应 训练分布不同于测试分布时, 训练信息能否帮助测试任务?	观测核、概率测度与经验测度 Ξ_s, J_t, P_s, P_t 学习映射与随机输出律 $\hat{J}_n, A, \Lambda_D$	来源观测与目标风险的连接 (问题 17.3) 训练信息对测试目标的识别与风险估计 观测律与风险积分的扰动 (问题 17.4) 固定模型在训练与测试分布间的风险差 数据依赖输出的泛化与超额风险 (问题 17.21) 数据依赖候选的超额测试风险 重新学习后的预测与风险响应 (问题 17.23) 迁移表示或参数后学习结果的比较
元学习与多任务学习 训练任务的经验能否支持测试 任务中的适应和任务间取舍?	目标泛函、可行集与解集映射 $F, \mathcal{K}, S$ 学习映射与随机输出律 $\hat{J}_n, A, \Lambda_D$	多目标、尾部风险与取舍 (问题 17.13) 多个任务的联合要求与取舍 内外层优化及内层误差 (问题 17.14) 任务内适应与任务层外部评价 数据依赖输出的泛化与超额风险 (问题 17.21) 任务层与任务内抽样的分层泛化
在线与持续学习 训练样本持续到达时, 能否适 应变化并保持旧任务能力?	观测核、概率测度与经验测度 $P, \hat{P}_D, Q_n$ 目标泛函、可行集与解集映射 $F, \mathcal{K}, S$ 计算算子与迭代序列 $C, T_{D,k}, (v^{(k)})_k$ 学习映射与随机输出律 $\hat{J}_n, A, \Lambda_D$	经验积分的一致估计 (问题 17.2) 依赖训练样本的条件积分与统计误差 多目标、尾部风险与取舍 (问题 17.13) 新任务适应与旧任务保持的联合要求 数据或更新改变后的轨迹响应 (问题 17.18) 时变更新的训练轨迹响应 跟踪与相对比较者的累计表现 (问题 17.19) 移动比较者、变化预算与累计损失 重新学习后的预测与风险响应 (问题 17.23) 新训练后旧任务的测试风险增量
离线强化学习 训练轨迹样本能否支持新策略 的价值估计与学习?	观测核、概率测度与经验测度 Ξ_β, J_π 计算算子与迭代序列 $C, T_{D,k}, (v^{(k)})_k$ 学习映射与随机输出律 $\hat{J}_n, A, \Lambda_D$ 联合策略、状态转移与轨迹律 π, T, P_ϵ^π	来源观测与目标风险的连接 (问题 17.3) 行为策略对目标策略的覆盖与价值识别 极限、选解与收敛速度 (问题 17.16) 价值或策略计算序列的求解精度 数据依赖输出的泛化与超额风险 (问题 17.21) 数据所选策略的价值估计误差与类内价值差距 长期价值、稳定与行为约束 (问题 17.26) 所选目标策略的长期价值与约束

续下页

表 17.2 (续)

机器学习问题	数学对象	数学问题
在线强化学习 边行动边取得训练轨迹样本时， 能否学好策略并满足行为要求？	观测核、概率测度与经验测度 $P, \hat{P}_D, Q_n$ 计算算子与迭代序列 $C, T_{D,k}, (v^{(k)})_k$ 联合策略、状态转移与轨迹律 $\pi, T, P_\varepsilon^\pi$	经验积分的一致估计（问题 17.2） 历史依赖训练样本的条件估计误差 极限、选解与收敛速度（问题 17.16） 训练状态序列的收敛与求解误差 跟踪与相对比较者的累计表现（问题 17.19） 策略学习的累计表现与比较者 观测选择的收益与预算（问题 17.25） 探索所获信息与采样成本 长期价值、稳定与行为约束（问题 17.26） 执行状态的长期价值、稳定与安全 环境或策略变化后的执行响应（问题 17.27） 策略或模型误差经反馈产生的执行偏差
主动学习与实验设计 如何选择训练样本或查询，在 预算内改善测试表现？	观测核、概率测度与经验测度 $K, P, Q_n, \hat{P}_D$ 学习映射与随机输出律 $\hat{J}_n, A, \Lambda_D$ 联合策略、状态转移与轨迹律 $\pi, T, P_\varepsilon^\pi$	目标的可识别性（问题 17.1） 允许查询是否能够区分学习目标 经验积分的一致估计（问题 17.2） 自适应采样后的积分估计误差 数据依赖输出的泛化与超额风险（问题 17.21） 查询后所选候选的泛化差与超额测试风险 观测选择的收益与预算（问题 17.25） 查询策略的信息收益与成本
多智能体学习 各方策略是否相容，学习与执 行能否达到要求？	计算算子与迭代序列 $C, T_{D,k}, (v^{(k)})_k$ 联合策略、状态转移与轨迹律 $\pi, T, P_\varepsilon^\pi$	极限、选解与收敛速度（问题 17.16） 联合训练序列的极限及其类型 跟踪与相对比较者的累计表现（问题 17.19） 各方累计损失与遗憾 长期价值、稳定与行为约束（问题 17.26） 联合策略执行的价值与约束 环境或策略变化后的执行响应（问题 17.27） 各方策略误差引起的执行响应 均衡存在与学习能否达到（问题 17.28） 均衡存在、平均均衡误差与达到条件

表 17.2 机器学习问题与数学问题的对应。同一机器学习问题合并为一个任务单元格，所需的各条数学路线分别列出；对象名称、问题名称及编号与表 17.3 一致。同一数学问题可以服务于多个学习任务，各路线的具体对象与比较量须按任务分别指定。

同一种分析可以用于不同对象，一个实际任务也会同时涉及多个对象。下一节保留表中的类型与比较量，按对象归类，并根据拓扑、光滑性、凸性、采样依赖和反馈结构，解释前面各章的数学知识怎样进入分析。

17.3 数学问题的归类、形式化与分析方法

第 17.2 节已经将机器学习任务写成对象与分析问题的组合。本节合并其中结构相同的问题，按数学对象分节，在每类对象下按分析问题分小节。小节名称沿用两表中的数学问题名称。每个小节先说明实际困难，再给出数学表述，解释相关条件为什么允许使用某种数学工具。阅读时可以先问：现在固定了什么、允许什么改变，最后想比较哪一个量？例如，同一条错误温度记录可以改变最优解、训练轨迹与最终报警，但这三个结果分别属于不同映射。它们可以共享扰动分析的思路，却需要各自的距离、条件与误差传递关系。训练数据变化与优化器变化都可能成为迭代序列的扰动；在压缩条件下可使用同一误差递推，在仅有局部光滑性时则不能照搬全局结论。

每个问题框规定对象、比较量及所求性质；相邻解释说明实际困难落在公式的什么位置，以及附加条件为什么使某类工具有用。分类是分析入口，不要求每种机器学习方法只属于一行：同一变分模型既有分布逼近问题，也有目标优化、数值求解和统计评价问题。具体模型中的推导、算法设计和保证条件，留待后续章节在各自场景中展开。前面各章的知识通过这些条件进入分析，而不是仅按术语名称作对应。以下概率保证假定随机量、事件及上确界可测，相关积分存在；涉及距离、拓扑或导数时，均应在相应对象空间上明确这些结构。

17.3.1 观测核、概率测度与经验测度

第 17.2.1 节的信息问题、第 17.2.3 节的估计问题与第 17.2.6 节的跨分布问题，都涉及概率观测。数据侧的对象包括观测核 K 、记录概率测度 $P = \mu K$ 、样本联合律 Q_n ，以及由实现样本构造的经验测度 $\hat{P}_D = n^{-1} \sum_{i=1}^n \delta_{Z_i}$ 。其中 $\hat{P}_D$ 在抽样前是随机测度，给定 D 后才固定。它们允许讨论观测能确定什么、有限记录估计得多准，以及数据规律变化产生什么影响。

17.3.1.1 目标的可识别性

在允许环境的集合上，固定观测与采样机制会给出观测映射 Ξ 。独立重复采样时可写为 $\Xi: \mathcal{E} \mapsto P$ ；一般情形应保留完整可观测联合律，不能只保留单条记录的边缘分布。另用 J 表示从环境到所求量的映射。先检查相同观测规律是否可能对应不同目标，再讨论有限样本估计。

数学问题 17.1 可观测规律是否确定所求量

给定允许的环境集合、固定观测与采样机制，以及从环境到完整观测规律的映射 Ξ 与到目标量的映射 J ，是否对任意两个允许环境都有

$$\Xi(\mathcal{E}) = \Xi(\mathcal{E}') \implies J(\mathcal{E}) = J(\mathcal{E}')?$$

若不成立，增加什么观测或结构条件，才能消除与目标有关的歧义？

可识别性 (identifiability) 排除的是与目标有关的观测歧义。例如，缺少必要工况字段、没有记录某种行动的结果，可能使目标在无限多现有类型的记录下仍不能确定。弱监督中的潜在标签、偏好数据对应的奖励、离线记录中的新策略效果，都需要检查这种关系。增加样本只能降低可估计量的不确定性，不能自行消除上述歧义。

要判断信息是否足够，可以先暂时假设已经知道完整观测分布，排除有限样本带来的误差。如果两种环境在此时仍不可区分，却要求不同答案，那么困难出在现有观测没有包含必要信息。增加同类样本或更换优化器都不能消除它。第 1 章的等价关系正好把这些环境分组；识别问题就是检查目标在每组内是否保持同一个值。

在线性观测中，这种歧义可以沿第 6 章的零空间来寻找：哪些真实变化没有改变读数？图像恢复、潜变量模型和隐藏状态估计都可能遇到这一问题。若目标是“改变散热动作以后会怎样”，还要区分观测条件与真实干预，使用第 12 章的结构假设。可识别以后，有限数据能否准确恢复目标仍是下一层统计问题。

来源融合、缺失数据和奖励学习也要先核对观测机制：两个标签来源可能复制同一判断，缺失记录可能集中于某类工况，偏好只可能确定奖励的某些相对关系。需要说明这些信息来源之间的联合分布、条件独立关系，或者补充已知标签、已知参数等参照信息，才能判断目标究竟可以确定到什么程度。

17.3.1.2 经验积分的一致估计

经验风险与总体风险分别是损失函数对 $\hat{P}_D$ 与 P 的积分。可根据采样假设，研究这些积分的偏差、集中程度及随样本量增长的极限。

数学问题 17.2 有限观测对总体泛函的近似

给定记录分布 P 、采样机制 Γ_n 、损失函数类 $\{\ell(h, \cdot) : h \in \mathcal{H}_e\}$ 及经验测度 $\hat{P}_D$ ，对指定精度与置信度，能否控制

$$\sup_{h \in \mathcal{H}_e} \left| \int \ell(h, z) P(dz) - \int \ell(h, z) \hat{P}_D(dz) \right| ?$$

所需样本数如何依赖损失类、抽样相关性与精度要求？

这是对一族积分的共同控制。它若成立，就可以用于该类中由数据选出的候选。只对抽样前固定的一个 h 得到的误差界，不能直接代入同一批数据选出的 h_D 。学得模型的风险还取决于学习规则怎样选择候选，后面在学习映射上继续分析。

单个温度预测器的平均误差会随抽样波动；从许多候选中挑出经验误差最小者，还可能挑中一次偶然的低估。一致估计需要同时限制这种选择机会。有限候选时，第 10 章的集中不等式控制每个候选，第 2 章的计数配合联合界控制全部候选。无限候选需要描述有效规模：有限覆盖见第 5.2.3 节，打散与候选计数见第 2.1 节，对称化与随机复杂度见第 10.4.2.2 节。

采样方式决定这条路线能否使用。记录独立同分布于 P 且损失有界时，可以用集中不等式控制相对 P 的积分误差；无界损失要增加矩或尾部条件。无放回、分层和按设备成组抽样，应按实际入样设计分析方差；按历史选择的记录则要保留条件信息，考虑鞅或其他依赖工具。少量独立设备上的大量记录，不能直接当作同样数量的独立环境。

相关样本可由协方差检查均值波动，或在混合条件下通过分块接到集中工具。自适应样本则常先减去历史条件期望，构造鞅差；控制了这部分随机波动以后，还需解释随历史变化的条件均值如何联系目标风险。因此，即使记录数量相同，能够支持估计的证据也可能相差很大。

17.3.1.3 来源观测与目标风险的连接

旧工况与新工况对应 P_s 和 P_t 时，需要规定二者的联系，以及来源记录能够支持哪些目标积分。

数学问题 17.3 来源观测与目标风险的连接

给定来源观测律 P_s 及其采样数据 D ，目标风险泛函 $R_t : \mathcal{H}_e \rightarrow \mathbb{R}$ ，以及允许的来源与目标关系，能否由来源观测识别并估计 $R_t(h)$ ？怎样构造 $\hat{R}_D$ ，使

$$\sup_{h \in \mathcal{H}_e} |R_t(h) - \hat{R}_D(h)|$$

得到有用的界？若学习规则在可行类中近似最小化 $\hat{R}_D$ ，能否结合其求解误差，控制输出候选的目标超额风险？

固定预测任务中取 $R_t = R_{p_t}$ 。离线策略评价则使用行为策略 β 诱导的轨迹律 $P_{\mathcal{E}}^{\beta}$ ，估计新策略 π 诱导的目标量；目标轨迹律本身还依赖 π 。若来源记录没有包含目标需要的情形，且没有额外规律说明这些情形之间的联系，来源记录就不能自动确定目标表现。少样本迁移、元学习与领域泛化可以改变共享信息和允许目标族，但仍需写清来源证据与目标量的联系。

固定来源与目标的静态任务中，应分别追踪有限来源样本的误差、来源与目标的风险差异及有限求解误差。增加来源样本可以降低抽样误差，却不能自行消除来源与目标的差异，或补足算法的求解步骤。若还用这些样本选择 h_D ，需要考虑模型选择造成的统计影响。迁移到不同输出或损失的任务时，则先规定共享表示或参数怎样进入新的目标泛函。

来源记录能够支持目标评价，关键在于它是否见过目标需要的情形，以及二者在这些情形下有什么关系。若目标分布对来源分布绝对连续且密度比可确定，第 10.3.3 节的换测度允许重新分配已有记录的贡献。重要性加权由此获得数学依据；来源从未覆盖的情形却不能仅靠增大权重补出来。监督任务若只按输入密度比加权，还需保证给定输入后的标签规律保持不变。仅使两个输入表示分布相似，不能排除它们要求不同标签；分布对齐需要另行连接任务风险³。

能够改写积分，还不等于能够稳定估计积分。大权重会放大抽样波动，未知权重还带来额外估计误差，这时要回到第 10 章核对加权变量的矩与集中条件。因果效果和离线策略评价还需相应的识别与覆盖假设；使用结果模型辅助校正时，也要分别保留各估计环节的误差和数据依赖。

在离策略评价中，这些条件作用于轨迹或状态与行动的访问分布，相关访问量可联系第 15 章的占用度量。环境与观测机制相同时，可以由策略的行动概率组织轨迹换测度，但必须保留实际使用的信息历史；长轨迹中的权重波动也可能很大。如果行为策略从未执行强散热，两个环境就可能在来源记录上完全相同，却赋予使用强散热的目标策略不同价值。没有覆盖或额外结构关系时，来源分布的精确真值也未必能识别目标价值。

根据同一批记录选择策略，还可能选中被偶然高估的候选，需要对候选集合共同控制评价误差，或另用独立数据评价。按不确定性界保守选择、限制策略访问低覆盖区域，分别联系统计控制与可行集合设计。这些选择是否改善目标价值，需要后续强化学习场景中的条件与证明；修改后的价值或策略更新能否收敛，则属于计算序列分析。

17.3.1.4 观测律与风险积分的扰动

固定可积测试函数类 $\mathcal{F}$ ，比较记录律 P, P' 的积分，以及样本联合律 Q_n, Q'_n 的距离。单条记录的边缘律接近，并不自动保证整批样本联合律接近。

数学问题 17.4 观测规律与风险积分的扰动

在共同的情形空间与记录空间上，给定 (μ, K, Γ_n) 及允许的变化 (μ', K', Γ'_n) ，令相应记录律为 P, P' ，样本联合律为 Q_n, Q'_n 。给定可积测试函数类 $\mathcal{F}$ 与样本律距离 d_{law} ，能否控制

$$\sup_{f \in \mathcal{F}} |\mathbb{E}_{P'} f - \mathbb{E}_P f|, \quad d_{\text{law}}(Q'_n, Q_n)?$$

记录边缘律的控制是否足以支持所需的整批样本结论？

选择分布距离，应从最后要比较的量倒推。若关心越限事件的概率，总变差直接比较事件；若关心温度的平滑变化，可以把新旧情形配对，再用函数对距离的响应控制积分差，这就引出耦合与 Wasserstein 距离。第 11.3.1 节说明了这两种连接，距离的选择因此与损失的正则性有关。

比较记录分布还要注意样本之间的关系。两批记录可以具有相同的单条边缘分布，却有完全不同的相关性，从而使均值估计和学习结果有不同波动。因此，环境或观测改变后的积分比较，与整批样本联合律的比较，需要各自的条件。无界成本及罕见极端情形还要求检查尾部，不能仅由一般的分布接近推出任意风险接近。仅观察 P 的变化，通常也不能唯一判断是环境频率 μ 还是观测机制 K 改变了。若记录空间或传感器维度改变，应先构造共同表示；若要逐次比较两批样本及学习输出，还要规定联合抽样或耦合。

17.3.1.5 覆盖、校准与条件风险

在温度预警中，越限概率、区间覆盖和接受预测后的错误率，对应不同事件或条件期望。

数学问题 17.5 预测与决策的概率关系是否满足要求

给定测试分布 P 、概率预测器 $p(X)$ 、预测集合规则 $C_D(X)$ 或接受事件，所声明的概率关系是否成立？二元标签 $Y \in \{0, 1\}$ 的理想校准，以及一般标签空间中的边缘覆盖，分别要求

$$\begin{aligned} \mathbb{E}[Y \mid p(X)] &= p(X), \\ \mathbb{P}\{Y \in C_D(X)\} &\geq 1 - \alpha, \end{aligned}$$

其中 $\alpha \in (0, 1)$ 是允许未覆盖概率。校准式针对固定预测器和新记录的联合律，等式在几乎处处意义下成立；覆盖式若未另作条件说明，对构造集合所用数据、算法随机数及独立新记录共同取概率。接受部分的条件风险、指定群体的条件率是否满足给定限制，有限观测能以多大置信度支持这些声明？

可靠性 (reliability) 要回答的是：模型报告的概率、区间或可接受决定，是否与实际发生的频率和错误代价相符？第 17.2.4 节先固定训练结果，再研究新记录的覆盖率；上面的边缘覆盖则还对构造预测集合的随机性取平均。后者成立，不意味着每次训练得到的预测集合都具有同样的覆盖率。边缘覆盖不自动保证每个输入或群体的条件覆盖，概率校准也不等于错误率很低。公平性要求若采用群体正预测率或条件错误率，就在相应群体条件分布上规定并检验关系。这些关系能否从有限数据估计属于本类对象的问题；是否存在同时满足关系的候选，则属于下面的可行集合分析。

可靠性声明最终要落到可观察的事件上。例如，区间是否覆盖真值可以记为一个指示变量，于是固定预测规则、独立测试条件下的覆盖率验证，就成为第 10.5 节的比例估计或检验问题。样本量决定证据的精度；没有观察到失败，也仍需估计尚未排除的失败概率。

有些保证来自构造本身。条件于训练信息，若校准记录与新记录共同可交换，并使用训练后固定的同一评分函数，或对全部记录作对称的评分构造，新记录的秩就具有可利用的概率结构，这连接第 10.5.3.2 节的预测集合方法。反复选阈值、比较群体或边看结果边停止，会改变所需控制的事件族，应使用同时或序贯有效的论证。后验可信度、重复抽样的置信度和未来结果的覆盖率也分别描述不同的随机对象。

17.3.1.6 条件化、积分与生成

前面的 P 描述现实记录的分布；这里固定已经给定或已经拟合的模型，研究模型内部的计算。例如，观测到温度与报警以后，要求隐藏故障的条件分布；生成未来读数，则要求从规定的模型分布取样。模型参数此时保持不变，仍然可能要求解一个复杂的计算问题。在进行计算以前，也要核对模型的结构语义：给定 W_3 后， W_1 与 W_2 是否条件独立，即相应条件联合分布是否等于两个条件边缘分布的乘积，以及图上的分离关系为何能表达它。第 10、9 章将这一问题接到条件概率与图分解；正性、因子化和因果假设各有不同作用，概率图中的箭头本身不等于现实干预关系。

数学问题 17.6 模型分布上的条件化、积分与生成

给定模型联合密度 $p_\theta(w, e)$ 及证据 e ，其中 w 是未观测量， λ 是其基准测度，且

$$0 < Z_\theta(e) = \int p_\theta(w, e) \lambda(dw) < \infty,$$

能否计算条件分布 $\Pi_\theta(dw | e) = p_\theta(w, e) \lambda(dw) / Z_\theta(e)$ ，以及给定可积函数 f 的积分 $\int f d\Pi_\theta$ ？若只构造近似分布或生成样本，应以什么距离、查询误差和计算预算评价结果？

要从联合分布得到隐藏故障的概率，需要对无关变量求和或积分，再条件于已经观察到的证据。这些操作的依据见第 3、10 章。图上的条件独立与局部分解允许重新组织这些运算：变量消除及树或合法树分解上的精确消息传递复用中间结果，但成本取决于产生的中间因子与图的消元宽度，而不只是原图的边数，连接第 9 章。有环图上的迭代消息是否收敛、所得结果是否准确，还需另外分析。最大概率配置则把求和问题换成优化问题；混合求和与最大化时，二者通常不能任意交换次序。

精确计算困难时，可以限制近似分布的集合，用散度或变分泛函选择一个便于计算的替代，这把第 11 章接到目标泛函与优化上。Laplace 近似利用局部二阶结构，矩匹配保留指定积分，Monte Carlo 方法通过随机样本近似积分；它们丢弃的信息和误差来源不同。模型误差、近似族误差、求解误差与抽样误差应分别分析，后验计算准确也不能独自证明模型描述了现实。可逆生成映射则把基础分布推送到输出空间，在相应可微与可逆条件下使用第 3 章的变量替换计算密度。能够生成样本、能够计算某点的密度、能够给定证据后计算条件分布，是三种不同能力。具备其中一种，不能自动推出另外两种。

17.3.2 候选函数、函数类与表示映射

第 17.2.1 节的表达、模型压缩和行为解释，与第 17.2.4 节的输入鲁棒性，可以在同一类函数对象上提出。在监督预测中，单个候选是可测函数 $h: X \rightarrow Y$ ，候选类 $\mathcal{H}$ 是这样的函数组成的集合，参数化 $\Phi: \Theta \rightarrow \mathcal{H}$ 则把参数映成函数。在密度建模或策略学习中，候选可相应换成分布或概率核。先分析候选本身及其集合，可以区分表达范围与某次训练实际选出的结果。

17.3.2.1 精确表示与最佳逼近

给定希望表达的对象 g ，先判断它是否在允许范围内，再讨论最好能接近到什么程度。研究这个问题，是因为训练只能从允许范围中选择候选：固定范围下的最佳可能误差，是评价任何学习方法共同参照。沿用 $\Theta_c = \{\theta \in \Theta: \Phi(\theta) \in \mathcal{C}\}$ 表示可行参数域，以实际允许的像 $\Phi(\Theta_c)$ 为分析范围。

数学问题 17.7 目标的表示与逼近

给定候选对象所在空间 H 、参考对象 $g \in H$ 、表示映射 $\Phi: \Theta \rightarrow \mathcal{H} \subseteq H$ 、非空可行参数域 $\Theta_{\mathcal{C}}$ 及距离 d_H ，是否有 $\theta \in \Theta_{\mathcal{C}}$ 满足 $\Phi(\theta) = g$ ？
若没有，

$$\inf_{\theta \in \Theta_{\mathcal{C}}} d_H(\Phi(\theta), g)$$

有多大，能否由某个候选达到？

温度规律、已有模型的行为和策略都可以作为这里的参考对象。网络宽度、低秩结构或对称限制改变表示范围；参数变多也可能只是重复表示已有函数，不必然增加可表示对象。精确相等应按任务规定为逐点相等或几乎处处相等；不能精确表示，也不一定意味着逼近误差有正下界，目标还可能位于候选范围的闭包中。扩大候选范围改变最佳可能表现，却不单独决定有限样本、有限计算下学得模型的风险。

表示学习还应检查压缩映射是否保留任务需要的区别。用简单模型解释复杂模型时，若要求解释忠实于指定输入区域内的预测行为，也可转为相同的函数逼近问题。

逼近分析把“模型不够用”变成空间中的距离问题。若候选构成 Hilbert 空间中的闭线性子空间，并以该空间的范数衡量误差，最佳逼近就是把目标正交投影到该子空间；若候选由有限基或低秩矩阵表示，就可以用秩与谱分解查看哪些方向被保留、哪些被舍弃。这些路线分别来自第 5、6 章。

非线性网络、核空间和图上的表示仍沿用“目标空间、候选限制、误差尺度”的问法，但可用的逼近结论随结构改变。压缩、蒸馏和量化还要说明保留的是原模型行为、重构质量还是下游风险；一种距离小，未必使另一种代价也小。多个候选组合时，平均后的波动取决于成员误差的协方差，可联系第 10 章，不能只按成员数判断收益。

17.3.2.2 固定函数的输入响应与分布风险

训练完成并固定 h 以后，输入变化作用于 h 本身，比较其输出或损失。

数学问题 17.8 固定预测器的局部扰动与分布风险

给定固定候选 h 、输入 x 、允许变化集合 $\mathcal{U}(x)$ 及输出距离 d ，能否控制 $\sup_{x' \in \mathcal{U}(x)} d(h(x'), h(x))$ ？若原标签 y 在该范围内仍有效，最坏损失

$$\sup_{x' \in \mathcal{U}(x)} \ell(h, (x', y))$$

有多大？若改变的是整体现实频率，则对给定分布集合 Ω ，能否控制 $\sup_{Q \in \Omega} R_Q(h)$ ？

局部输入鲁棒性不要求事先存在一对训练、测试分布。分布鲁棒性则将同一个 h 放到一族概率测度下积分，也调用上一类对象的分析。只有规定样本对应关系、标签是否保持以及允许的扰动机制后，才能联系两种保证。一般分布变化还可能改变标签规律或进入未覆盖区域，不能一律当作小输入扰动。输入攻击在此额外规定攻击者的信息、可修改字段和预算；少数攻击未成功不能证明全体允许输入上的保证。

小的输入变化会不会引起大的输出变化，取决于映射怎样放大距离。在线性情形中，算子范数直接描述最大的放大比例；在光滑非线性情形中，Jacobian 先描述一个点附近的线性响应，再由余项或整个区域上的导数控制，判断这种局部描述能否覆盖允许扰动。这分别连接第 6、3 章。

若输出经过报警阈值，即使温度预测只变化一点，决策也可能翻转，还要检查原输出离阈值有多远。要证明所有允许扰动都满足要求，必须对整个允许集合建立有效的界。区间传播、凸松弛或约束搜索可以服务这一目的；一次攻击则只是检查一个特定扰动，攻击成功可给出反例，失败不能证明全体扰动都安全。随机平滑还需把噪声下的事件概率与输入变化联系起来。对于流形上的姿态或形状变化，允许路径与距离应按第 7 章来定义。

同一响应分析也能服务解释，但必须先规定解释量。梯度描述局部变化，路径积分累计沿指定路径的变化；按特征子集比较输出，则得到集合函数上的边际贡献，可联系第 16 章的 Shapley 分配。基线、缺失特征的补全规则与允许路径都会影响答案；这些函数归因不自动等于现实中的因果作用。

17.3.2.3 对称结构与信息保留

交换传感器编号只是重新描述同一个设备，节点级预测应随编号一起交换；若输出是整台设备的报警结论，编号改变又不应该改变这个结论。这类要求规定的是变换前后输出的对应关系，不等于任意输入扰动都应得到相近数值。

数学问题 17.9 候选映射的对称结构与信息保留

给定群 G 在输入与输出空间上的作用，候选 h 是否对允许的 $g \in G$ 、 $x \in X$ 满足

$$h(g \cdot x) = g \cdot h(x)?$$

输出作用为恒等时得到不变性。若只要求近似成立，如何控制两侧的距离？给定压缩表示 $r: X \rightarrow Z_r$ 与任务函数 f ，是否存在 $\tilde{f}$ 使 $f = \tilde{f} \circ r$ ？

第 7.1.3 节用群作用明确“同一种变化”在两个空间上的含义。平移、置换和旋转分别连接卷积、图传播与几何表示；逐层满足相应关系时，还要

检查组合、池化和边界处理是否保留它。第 8、9 章的频率与谱工具，则帮助判断反复传播会保留或抑制哪些变化。

信息保留问的是另一件事：表示把哪些输入合并了，这些输入是否仍需要不同答案。若已经合并了任务必须区分的情形，后面的预测头便无法重新制造这一区别。这将表示坍塌、图传播中的过平滑、瓶颈压缩与前面的可识别性联系起来；但统计方差、秩或局部距离只是观察表示的不同量，单项正常不等于任务信息已经充分保留。

17.3.3 目标泛函、可行集与解集映射

第 17.2.2 节的训练可行性和第 17.2.5 节的目标变化，都需要先分析优化问题本身。固定样本 D 后，目标构造规则给出实值泛函 F_D 和训练可行集 $\widehat{\mathcal{H}}_{c,D}$ 。它们共同定义一个优化问题，尚未指定采用什么算法求解。研究总体目标时可将 F_D 换成 R_P ，并使用真实可行集 $\mathcal{H}_c$ 。

17.3.3.1 可行性、极值存在与最优条件

为便于陈述，下面先考虑训练可行集已知且等于 $\mathcal{H}_c$ 的情形。

数学问题 17.10 目标泛函的极小值与解

固定训练样本 D ，给定可行候选集合 $\mathcal{H}_c$ 及其上的目标泛函 F_D ： $\mathcal{H}_c \rightarrow \mathbb{R}$ 。下确界 $\inf_h F_D(h)$ 是否有限、是否能够达到？极小值的解集合 $\arg \min_h F_D(h)$ 是否非空，解是否唯一，哪些条件能够刻画全局最优或局部驻点？

采用参数化以后，优化目标变为 $f_D = F_D \circ \Phi$ 。同一函数可能对应多个参数，函数解唯一不意味着参数解唯一；参数目标上的梯度为零，是否意味着函数已经最优，也取决于 Φ 怎样把参数映成函数。增加报警约束或群体条件率要求时，还应先确认可行集合非空，不能以优化器未找到解就断定约束不可同时满足。

极小值问题首先要防止两种情况：可行集合为空，或者目标不断下降却没有任何候选达到下确界。非空紧域上的连续目标可由第 3.3.1 节的极值定理保证达到下确界；非紧域中的下半连续性、强制性及解存在条件见第 4.1.2 节。这些条件分别排除无极小点的不同来源，不能由“采用了一个优化器”代替。

解存在以后，才讨论怎样判定最优。凸性使局部信息能够支持更强的整体结论；约束资格条件决定第 4 章的 KKT 条件怎样使用。还可以用对偶问题给出的界，与一个可行候选的目标值相比较，估计距离最优还差多少，并据此决定是否停止。空间结构也可能使求解转为等价形式：平方损失与线性空间联系投影，有限评价点及适当范数惩罚下的核函数优化联系有限

系数表示，具体条件由第 5 章给出。离散标签、匹配或图结构选择则要利用组合搜索与图分解；连续松弛的值、取整后的可行值和原问题最优值必须分开。

最坏情形学习可以把允许扰动下的最大损失作为新的目标泛函，再选择使它较小的候选。内层是在找最不利情形，外层是在改模型；交换两层次序需要极小极大条件，交替更新的稳定性还要另证。一次未充分求解的攻击只得到内层最大值的下界，因此不能直接充当鲁棒目标已经被准确计算的证据。这连接第 4 章的对抗优化与对偶分析，也回到计算算子的误差问题。

17.3.3.2 代理目标与任务目标的关系

为了便于求导，报警系统可能最小化一个连续评分；使用者却关心漏报与误报的实际代价。连续评分不断下降，并不自动说明实际代价也下降。需要先建立两个目标之间的关系，才能判断代理优化是否解决了原来的任务。

数学问题 17.11 代理泛函能否支持真实目标

给定同一候选集合上的代理泛函 $\tilde{R}$ 与真实泛函 R ，假设相关风险有限且两个下确界有限，是否存在非减函数 $\psi : [0, \infty) \rightarrow [0, \infty)$ ，满足 $\psi(0) = 0$ 与 $\lim_{r \downarrow 0} \psi(r) = 0$ ，并对所有候选 h 都有

$$R(h) - \inf_g R(g) \leq \psi \left(\tilde{R}(h) - \inf_g \tilde{R}(g) \right) ?$$

若不能，哪些误差或遗漏的约束阻止了代理最优转成真实目标上的好结果？

这里的要求比“两个目标在若干候选上正相关”更强：它要控制所有所考察候选的真实超额风险。自监督目标、偏好评分和任务损失之间若缺少这种联系，代理优化收敛仍不足以证明真实要求得到满足。

代理目标的作用应通过它偏好的候选来解释。一种分析入口是固定输入，比较条件标签分布下的两种损失，再检查这种关系能否通过积分传到总体，连接第 10 章的条件期望与第 3 章的积分工具。

似然、对数评分和变分目标还可借助第 11 章的散度解释。但“优化下界”“拟合教师”“提高偏好评分”分别改变不同泛函，不能仅因为它们都能训练就视作同一目标。候选类受限、近似推断或遗漏行为约束时，目标之间可能留下无法由增加优化步数消除的差距。

17.3.3.3 最优值与解集的敏感性

令 η 表示当前可变化的配置，例如样本、损失权重或约束阈值。给定相应的泛函 F_η 和可行集 $\mathcal{K}_\eta$ ，定义

$$v(\eta) = \inf_{h \in \mathcal{K}_\eta} F_\eta(h), \quad S(\eta) = \arg \min_{h \in \mathcal{K}_\eta} F_\eta(h).$$

v 是最优值函数， S 是把配置映为解集合的集合值映射，可能为空或包含多个解。若新旧解均唯一，可以比较其函数距离；多解时则需规定集合距离或选解规则。

数学问题 17.12 最优值与解集对配置的敏感性

给定配置空间中的邻近关系与解空间中的距离， η' 接近 η 时，可行性是否保持， $v(\eta')$ 是否接近 $v(\eta)$ ， $S(\eta')$ 与 $S(\eta)$ 能否在规定意义下接近？若解唯一且具有相应光滑结构，能否求出解对配置的导数或定量误差界？

错标记录、正则权重与约束变化都能进入 η 。此处比较的是理想优化问题的解；有限步训练输出能否接近这些解，还需要分析实际更新序列。

解的敏感性关心的是：问题稍微改变，最好答案是否随之剧烈改变。若一个局部最优点由光滑方程确定，且相应导数可逆，第 3.3.5 节的隐函数方法就把“重新求解”转成“研究这条解分支如何移动”。条件数描述其中可能的放大，是第 6 章的入口。

约束阈值变化还可能使原来不起作用的约束变成紧约束，或者让可行集合消失。这需要第 4.4.3.4 节的乘子、活动约束及可行性分析。出现多解或分支切换时，单个解的导数可能失去意义，应比较解集合或明确选解规则。训练点影响、目标权重调整和知识编辑可共享这一入口，但实际有限步模型还要保留求解误差。最优值接近不自动保证解接近；强凸曲率或局部非退化结构，才可能把目标或梯度的变化转成解的距离控制。若新旧目标采用不同单位或代价，还应在共同任务指标下比较各自输出，而不能只比较两个最优值的大小。

17.3.3.4 多目标、尾部风险与取舍

温度报警的漏报代价、误报代价和散热能耗未必能用同一个自然单位计量。给它们加权是一种目标选择，把其中若干项变成约束是另一种选择；数学分析需要保留这种区别。

数学问题 17.13 向量目标、风险泛函与可行取舍

给定可行集合 $\mathcal{K}$ 和实值目标 $R_1, \dots, R_m$, 是否存在 $h^* \in \mathcal{K}$, 使不存在另一个 $h \in \mathcal{K}$ 满足所有 $R_j(h) \leq R_j(h^*)$ 且至少一项严格小于? 若改权重 $w_j \geq 0$, $\sum_j w_j = 1$ 的标量目标 $\sum_j w_j R_j$, 或约束 $R_j \leq c_j$, 会选择哪些取舍, 哪些要求可能无法同时满足? 若将均值替换为给定损失随机变量上的风险泛函 ρ , 上述比较与可行性怎样改变?

问题中的不被支配条件就是帕累托有效性。它说明没有另一个候选能在不损害任何一项的情况下改善某项, 却没有替使用者决定应偏好哪个取舍。第4章的凸集合、标量化与约束分析可用于研究可达目标区域; 公平要求、资源限制与多任务目标都可以进入这一对象, 但具体指标的正当性仍来自任务定义。共同下降方向、驻点和最终不被支配的结果, 应各自陈述条件。

平均风险之外的尾部、分位或动态风险, 需要先说明随机损失及 ρ 的定义, 再联系第15章的风险评价。压缩中的码率与失真、推荐中的收益与覆盖、知识修正中的改动成功与旧能力保持, 都可以形成多项目标; 比较这些目标时, 须说明每项成本的单位, 以及平均值代表哪些人、设备或任务。若成本是编码长度, 还可用第11章的信息量解释码率, 再与量化、重构或下游任务损失一起比较。

17.3.3.5 内外层优化及内层误差

选择正则权重或模型架构时, 我们并不直接评价这个数值或结构, 而是先用它训练模型, 再评价所得模型在验证集上的表现。因此, 配置选择通过内层训练影响外层评分。元学习中的初始化和更新规则也有相同的依赖次序。

数学问题 17.14 通过内层学习进行外层优化

给定配置集合 Λ , 每个配置 η 对应候选集合 $\mathcal{H}_\eta$ 、实值训练目标 F_η 及输出属于 $\mathcal{H}_\eta$ 的有限步学习映射 $A_\eta^{(k)}$ 。给定训练记录 D_{tr} 、验证记录 D_{va} 与实值外层评价 J , 固定算法随机数 U , 研究

$$\inf_{\eta \in \Lambda} J\left(\eta, A_\eta^{(k)}(D_{\text{tr}}, U), D_{\text{va}}\right).$$

该外层目标是否可计算、可微或稳定? 若改用理想内层解集

$$S(\eta) = \arg \min_{h \in \mathcal{H}_\eta} F_\eta(h),$$

应采用什么选解规则, 替代有限步输出的误差有多大?

有限步内层是若干映射的复合,可以沿第 3 章的链式法则传播外层变化;局部唯一且非退化的理想内层解,则可联系隐函数方法。二者分别对实际计算路径和理想解分支求导,未必得到相同结果。若内层含随机采样,交换求导与积分还需相应条件;多解、离散架构和非光滑切换则需要另选分析方式。外层反复使用验证数据产生的选择偏差,最后仍要交给统计分析。

17.3.4 计算算子与迭代序列

第 17.2.2 节的收敛与计算问题,以及第 17.2.5 节中数据或优化器改变后的轨迹问题,共同归到更新算子与序列上。选择求解方法以后,才产生具体训练状态序列。以 V 表示状态空间,状态 $v^{(k)}$ 可以包含参数、动量、价值估计或其他辅助量。这里用 v 表示计算状态,以区别记录 $z \in Z$ 与预测输入 $x \in X$ 。固定算法随机数时,一次更新可写为 $T_{D,k} : V \rightarrow V$;若依赖历史,可以将所需历史并入状态。

17.3.4.1 计算正确性、近似误差与资源

计算状态不限于训练参数。固定概率模型中的消息、图网络内部状态、数值积分的中间量,也由算子逐步产生。把这些过程放到一起,是因为它们都需要说明“所算对象、实际操作与误差”;是否更新模型参数只是具体用途的区别。

数学问题 17.15 计算结果的正确性、近似误差与资源

给定精确计算目标 $C : B \rightarrow C$ 、允许输入 $x \in B$ 、输出距离 d_C 及预算为 b 的实现 $\tilde{C}_b$, 是否有 $\tilde{C}_b(x) = C(x)$, 或能控制 $d_C(\tilde{C}_b(x), C(x))$? 若输出为最优配置,应改用规定的可行性与最优性残差。达到误差 ϵ 需要多少运算、存储、查询或通信,各项代价怎样依赖输入规模与精度? 随机实现还应规定误差保证的概率意义。

精确计算需要论证一系列操作没有改变所求对象。图上的消元与动态规划可用分解和归纳说明这一点;矩阵分块、卷积变换与缓存复用则要检查代数等价及各自成本,连接第 2、6、8、9 章。减少访存、减少算术量和减少候选搜索是不同改进,不能只用一个“更快”概括。

近似计算需要额外追踪偏差。截断搜索、有限步求解、低秩替代、量化和数值离散化都会改变实际算子。自动微分在可微计算图上应用链式法则;随机梯度还要研究估计量的偏差与方差,路径导数、似然比估计和条件期望降方差分别需要自己的正则与采样条件。第 3、10 章说明这些导数和估计量成立的条件,后文再据此分析具体模型的实现。

17.3.4.2 极限、选解与收敛速度

收敛与计算分析研究一条序列怎样趋近目标。

数学问题 17.16 训练序列的极限与速度

固定 D ，给定配有距离 d_V 的状态空间 V 、初始状态 $v^{(0)}$ 及更新映射 $T_{D,k}$ ，构造

$$v^{(k+1)} = T_{D,k}(v^{(k)}).$$

是否存在 $v^* \in V$ 使 $d_V(v^{(k)}, v^*) \rightarrow 0$ ？极限是否满足所求最优性或不动点条件？能否给出所选误差 $r(k)$ 的衰减界，以及达到精度 ϵ 所需的计算量？

参数收敛、函数收敛、目标值收敛和残差趋于零是不同命题。例如，状态中包含辅助变量时，目标值只是状态经若干映射得到的一个实数，这个实数收敛不能单独保证整个状态收敛。随机更新产生随机序列，须进一步指定期望、依概率或几乎处处收敛。函数空间中的范数、弱拓扑与逐点比较也可能给出不同结论；例如 $L^2(P)$ 距离不区分零测集上的输出。从参数序列转到函数序列，需要检查表示映射的连续性。第 5 章的完备性与弱紧致性，决定哪些极限仍可在所选空间中讨论。具有相应光滑结构时，也可以用 $\dot{v}(u) = V_D(v(u))$ 描述连续计算轨迹，其中 u 是计算时间。

分析一条迭代，先要找出每一步有什么可控制的变化。固定线性更新可以通过矩阵幂研究不同方向上的放大与衰减，因此调用第 6 章的矩阵幂与谱。固定更新若是完备空间上的压缩自映射，则由第 3 章的压缩映射理论研究其唯一不动点。更新随步数改变时，仅有共同压缩系数还不够，还需检查不动点是否共同或怎样移动。渐近收敛仍可能伴随有限步的暂态放大，需继续检查矩阵幂的范数；非扩张映射只保证距离不增，也不足以单独推出普通迭代收敛。优化迭代通常改为追踪目标或某个势函数的下降；光滑性、凸性与非光滑结构决定采用何种下降或近端论证。

选用下降方法还要说明以什么几何度量“走一步”。预条件利用局部曲率调整方向与尺度；流形约束需要在允许的切方向上更新；自然梯度以预测分布的局部变化定义距离，连接第 7 章与第 11.4.3.2 节。凸性或 PL 条件等结构决定梯度信息何时还能控制最优值差，单有光滑性通常不能作同样判断。

随机更新还要区分平均方向、系统偏差和随机波动，使用第 10 章的条件期望与随机过程工具。图网络内部状态的反复传播、参数训练和策略评价都可以形成迭代，但它们的状态和极限目标不同。因此，分析必须说明收敛的是状态、目标值、分布还是残差，不能把其中一项自动换成其他项。在强化学习中，离策略记录的加权、价值自举与函数逼近都会进入实际更

新算子。数据覆盖支持价值识别，却不自动保证该算子稳定；应检查平均更新、估计偏差和采样依赖，再选择谱、下降或随机逼近工具。

即使已经知道训练会趋近最优，仍可能不知道它会选择哪个最优候选。当 S_D 有多个元素时，可继续研究更新规则的极限是否落在某个更小的子集中；若参数范数不断增大，则可改问归一化方向或预测函数是否有极限。这就是隐式选解分析：第 6 章的零空间与最小范数几何、第 4 章的最优性条件，解释不同初始化和更新怎样筛选候选。得到选解性质以后，还需要函数复杂度或稳定性分析才能联系泛化。用初始化附近的线性模型解释网络训练时，也应比较真实轨迹与线性化轨迹；核谱可以分析近似模型的方向与速度，却不能省略有限宽度和特征变化造成的误差。

17.3.4.3 不变律、分布极限与积分误差

随机迭代有时要趋近一个分布，而不是一个点。采样链应持续产生不同样本；要求每条状态轨迹收敛到同一点，反而不符合采样目标。

数学问题 17.17 随机计算的分布极限与积分误差

给定计算状态空间 W 上的转移核 M 、初始律 ν_0 及目标律 Π ，按 M 生成时间齐次 Markov 链 $(W^{(k)})_k$ ，其第 k 步边缘律为 $\nu_k = \nu_0 M^k$ 。 Π 是否不变， ν_k 是否在指定距离下趋近 Π ？对可积函数 f ，有限序列均值

$$\frac{1}{m} \sum_{k=1}^m f(W^{(k)})$$

与 $\int f d\Pi$ 相差多少？初始化、样本相关性和近似转移怎样影响误差？

第 10 章的 Markov 核与遍历分析，把保持目标分布、逐步接近目标分布、以及时间平均估计目标积分这三件事区分开。有限状态时可以进一步使用谱；更一般情形可考虑耦合与漂移条件。独立 Monte Carlo、重要性采样与序贯粒子近似，也需要按实际采样律检查大数定律、矩条件和相关性，不能只看样本条数。

生成中的扩散或流还可能要求在有限时间到达某个终端分布，目标并不是平稳分布。此时应研究规定的概率演化与其数值近似，连接第 13 章的过程与离散化工具。把宽网络表示为参数测度时，可以令状态空间本身由测度组成，再比较有限个参数与测度演化。这类更新可能依赖当前测度，不能一律写成上面的固定转移核；粒子数、计算时间和数据样本量是三个不同极限。

17.3.4.4 数据或更新改变后的轨迹响应

改变数据、初始化、步长或目标，会使初始状态或更新映射变化。即使变化来自数据端，只要所求量是训练轨迹的偏差，分析对象仍是这里的算子和序列。

数学问题 17.18 迭代轨迹对数据和更新规则的响应

给定同一状态空间上的两组更新

$$v^{(k+1)} = T_{D,k}(v^{(k)}), \quad \tilde{v}^{(k+1)} = \tilde{T}_{D',k}(\tilde{v}^{(k)}),$$

给定初始偏差以及数据和算子的变化范围，定义轨迹误差

$$e_k = d_V(v^{(k)}, \tilde{v}^{(k)}).$$

能否控制 e_k 随步数的变化？新序列是否仍满足可行性和所需收敛保证，达到给定精度的计算量改变多少？

例如，对两次固定随机数的梯度下降，替换一条标签会改变每步使用的梯度，逐步误差可能被更新映射衰减，也可能累积或放大。需要分析这种传播才能得到轨迹扰动界。两次训练分别收敛不意味着它们收敛到邻近结果；轨迹始终接近也不证明任一训练已经达到最优值。若模型架构改变了状态空间，应先给出共同表示或比较映射，不能直接相减不同维度的参数。

两次训练的差异有两个来源：已有偏差经过下一步更新后会怎样，以及这一更新本身又新增了多少偏差。先比较一步，再逐步累积，就把错标、梯度近似、低精度计算或更换优化器放到了同一个递推问题中。当映射在共同区域内有 Lipschitz 或压缩控制时，第 3 章的递推工具可以描述误差被放大还是被抑制。

连续时间模型沿用相同思路，只是将逐步累积换成沿时间的响应，连接第 13.3 节。分布式训练中的迟到更新、局部多步计算和聚合误差，也需先写入实际更新状态，再分析其传播。比较两条轨迹时，须规定两次运行的初值或初始偏差、随机性耦合与共同有效区域；不能在一个点附近线性化以后，就默认整个训练过程都满足同样条件。

17.3.4.5 跟踪与相对比较者的累计表现

当新数据在训练期间不断到来，更新算子与目标都可能随时间变化，这时可研究状态能否跟随移动的解集，或者在整个序列上承担了多少损失。

数学问题 17.19 序列相对于比较者的累计表现

给定反馈时序、候选序列 h_t 、第 t 轮损失函数 f_t ，以及预先规定的比较序列集合 $\mathcal{K}_T$ ，能否控制

$$\sum_{t=1}^T f_t(h_t) - \inf_{(g_1, \dots, g_T) \in \mathcal{K}_T} \sum_{t=1}^T f_t(g_t)?$$

控制需要怎样的反馈、变化预算和资源，能否使单位轮次的差趋于零？

这里 t 是交互或在线更新轮次， h_t 由此前允许的信息产生；它与固定数据上求解所使用的计算步 k 可以不同。固定比较者和允许移动的比较者定义不同遗憾问题。若允许目标任意迅速变化，就不能默认有跟踪保证，必须说明变化预算及反馈条件。持续学习还要单独评价旧任务表现，最终参数收敛不能替代累计损失或能力保留的要求。

累计表现允许每轮选择都不等于最优，却要求全部轮次加起来不能比规定比较者差得太多。在闭凸域、凸损失和受控次梯度条件下，可以追踪当前状态到比较者的距离：一次更新造成的距离变化与当轮损失差发生联系，再通过求和连接到累计指标。第 16.5.2 节的投影与势函数方法提供了这一分析入口。

若比较者会移动，就要同时支付追踪它的代价，变化预算因此成为问题的一部分。若只观察所选动作的反馈，还需分析反馈估计与探索造成的误差。低累计遗憾、平均策略满足某种均衡条件、最后一轮状态收敛，是三个不同要求；第 16 章说明它们怎样在额外条件下相连。

17.3.5 学习映射与随机输出律

第 17.2.3 节的泛化、第 17.2.5 节的重训响应和第 17.2.4 节的发布要求，都以学习结果为比较对象。有限步训练将整批记录映成一个候选。固定方法、目标和步数 k ，简记学习映射为 $A(D, U) = A^{(k)}(D, U)$ 。它的输入是数据组与算法随机数，输出是函数、分布或策略，因而不同于前面的单步状态更新。沿用 $\text{out} : \mathcal{V} \rightarrow \mathcal{H}$ 从最终状态读出候选，则在固定随机数时有

$$A^{(k)}(D, U) = \text{out}(T_{D, k-1} \circ \dots \circ T_{D, 0}(v^{(0)})),$$

其中初值与更新也可依赖 U 。这说明训练序列分析可以支持学习映射分析，但只观察输出 $A^{(k)}$ 并不能恢复整条计算轨迹。

17.3.5.1 统计恢复与一致性

如果学习的目的是恢复设备参数、群组、依赖图或真实密度，任务的误差就不一定是预测损失。需要先把“恢复正确”定义为一个目标空间中的距离或等价关系。

数学问题 17.20 估计映射的恢复误差与统计一致性

给定可识别目标 $J(\mathcal{E}) \in \mathcal{J}$ 、目标距离 $d_{\mathcal{J}}$ 及估计映射 $\hat{J}_n : \mathcal{Z}^n \times \mathcal{U} \rightarrow \mathcal{J}$ ，能否控制

$$\mathbb{P}_{D,U}\{d_{\mathcal{J}}(\hat{J}_n(D,U), J(\mathcal{E})) > \epsilon\}?$$

随样本数增加，该概率是否趋于零，是否能在规定环境族上统一控制？目标只确定到等价类时，应如何定义距离与成功事件？

估计误差可以来自抽样、模型错设和求解不足，应先看哪一部分随样本增加而消失。第10章提供估计、检验和渐近分析；矩阵或子空间估计还可利用第6章的谱扰动工具。结构恢复需要检查哪些弱关系在有限样本下可被区分，因果结构则另需第12章的识别假设。聚类标签置换、潜空间旋转与图的观测等价，都提示我们不要把一种坐标表示误当作唯一真实答案。

置信区域还要求控制覆盖事件；后验集中则考察给定数据后的概率质量。模型选择、缺失数据学习和结构搜索可以产生这些估计输出，但具体算法收敛不等于统计一致。这也是为什么泛化良好的预测器，仍可能不足以恢复被赋予物理解释的内部参数。

17.3.5.2 数据依赖输出的泛化与超额风险

当 $D \sim Q_n$ 且 $U \sim \nu$ 独立时， $A(D, U)$ 是随机候选，其输出律是 $(Q_n \otimes \nu)$ 经 A 的推前测度。泛化可以直接研究随机量 $R_P(A(D, U)) - \hat{R}_D(A(D, U))$ ，也可以结合求解误差，控制相对于候选类最好风险的差。对整个损失类建立一致界是一条路线，分析 A 对样本的依赖是另一条路线。

数学问题 17.21 给定学习规则的泛化与超额风险

给定样本与算法随机性 (D, U) 的联合律 $L_n \in \mathcal{P}(\mathcal{Z}^n \times \mathcal{U})$ 、可测学习映射 $A : \mathcal{Z}^n \times \mathcal{U} \rightarrow \mathcal{H}_{\mathcal{C}}$ 、可测评价泛函 $R : \mathcal{H}_{\mathcal{C}} \rightarrow \mathbb{R}$ 及可测估计准则 $\hat{R} : \mathcal{Z}^n \times \mathcal{H}_{\mathcal{C}} \rightarrow \mathbb{R}$ ，写 $\hat{R}_D(h) = \hat{R}(D, h)$ ，并假定类内风险下确界有限。定义

$$\Delta_{\text{gen}}^R(D, U) = R(A(D, U)) - \hat{R}_D(A(D, U)),$$

$$\Delta_{\text{exc}}^R(D, U) = R(A(D, U)) - \inf_{h \in \mathcal{H}_{\mathcal{C}}} R(h).$$

第一项是数据依赖输出的风险估计差，第二项是类内超额风险。能否给出 $g_n(\delta)$ 与 $e_n(\delta)$ ，使

$$\mathbb{P}_{D,U} \left\{ \begin{array}{l} |\Delta_{\text{gen}}^R(D, U)| \leq g_n(\delta), \\ \Delta_{\text{exc}}^R(D, U) \leq e_n(\delta) \end{array} \right\} \geq 1 - \delta?$$

若只求平均保证，应明确控制有符号期望、绝对误差期望，还是平均超额风险。

当样本与算法随机性独立时， $L_n = Q_n \otimes \nu$ 。主动或交互采样中的依赖则保留在联合律中，不要求事先分解为乘积。静态同分布情形取 $R = R_P$ 和经验风险准则，就回到第 17.2.3 节的两个误差。跨分布学习须按问题 17.3 构造目标风险估计器，不能直接把训练分布上的均值当成测试风险。离线强化学习则取 $R(\pi) = J_\pi(\mathcal{E})$ ，相应估计器也须评价该目标策略；策略依赖的轨迹律进入 R 的定义，不要求所有候选共用同一个轨迹测度。

泛化分析的困难在于，候选和评价它的训练数据并不独立。一条路线同时控制整个候选类，使算法无论选中谁都受到约束；另一条路线只研究算法实际输出，考察单条记录能改变多少预测损失，或输出保留了多少样本信息。前者连接函数类复杂度与集中工具，后者连接算法稳定性及第 11.3.2 节的信息分析。

如果还要比较类内最优风险，就应将统计差异与未充分求解的代价合起来；单独让其中一项变小不够。样本压缩利用输出可由少量记录重构的结构，PAC-Bayes 则比较随机预测器的先验与数据依赖分布，分别连接第 2 章的编码计数与第 11.3.2.2 节。这些方法的随机单位和量词不同，平均有符号偏差、绝对误差期望和高概率界不能只凭名称互换。

分布形式的候选必须再说明随机单位。若学习输出是完整预测器上的分布 ρ_D ，使用时抽取 $h \sim \rho_D$ ，其评价量是 $\int R_P(h) \rho_D(dh)$ ；若 ρ_D 表示一个网络内部的神经元分布，则先由积分构造一个确定性的函数，再评价这个函数的风险。两种情况下都出现积分，却不能直接交换“先平均模型”和“先计算损失”的次序。这一区分决定可以使用 PAC-Bayes 的先验后验比较，还是测度表示的逼近与稳定性工具。多任务或环境层采样也要保留分层结构，不能把任务数与每个任务内的记录数合并成一个样本量。元学习以经过任务内适应后的风险评价规则，既要控制任务内有限样本误差，也要控制有限训练任务带来的误差。若未来任务的分布也不同，还需回到来源与目标的联系；任务内求解收敛不能替代任务之间的泛化⁴。

17.3.5.3 统一学习规则的存在与复杂度

可学习性 (learnability) 讨论在指定问题族上具有统一保证的学习规则是否存在。规则族 $\{A_n\}$ 的计算预算可以随 n 和精度要求配置；这比某批数据、某个分布或某次初始化下训练成功更强。样本复杂度、可计算性和高效性分别约束样本量、程序实现与资源，不能相互替代。在来源与目标分布不同时， A 的目标风险保证还需要前述来源与目标之间的联系。

数学问题 17.22 具有统一保证的学习规则是否存在

给定可行候选类、损失及允许的分布族，假定各分布下类内风险下确界有限。是否存在输出可行候选的学习规则族 $\{A_n\}$ (按样本数 n 选用，简记为 A)，使对任意 $\epsilon > 0$ 、 $\delta \in (0, 1)$ ，存在有限阈值 $n_0(\epsilon, \delta)$ ，当 $n \geq n_0(\epsilon, \delta)$ 时，将 A 的候选输出记为 h_D ，即 $h_D = A(D, U)$ ，对族内每个 P 及独立样本 $D \sim P^n$ 都满足

$$\mathbb{P}_{D,U} \left\{ R_P(h_D) - \inf_{h \in \mathcal{H}_c} R_P(h) \leq \epsilon \right\} \geq 1 - \delta?$$

所需样本数如何增长，该规则能否由可停机程序实现，所需计算资源有多大？

证明上述类内可学习性，通常要提出一族规则，并说明统计误差与求解误差能否达到要求。若还与候选类之外的理想决策比较，则另需加入候选类的逼近误差。这把第 5 章的函数类规模、第 10 章的估计条件和第 4 章的求解方法接在一起。容量条件的作用随损失和输出类型改变，二分类中的刻画不能未经检查搬到一般多分类或实值损失。

要说明任何规则都做不到，则可以构造观测难以区分、却需要不同决策的问题，使用第 11.2.4 节的检验与信息下界。即使统计上存在规则，第 2.3 节仍要求说明它能否停机、需要多少查询和计算。样本、算术操作、存储与通信是不同资源；只有访问方式和精度标准相同，上下界才可以比较。

17.3.5.4 重新学习后的预测与风险响应

固定随机数 U ，把样本变化传入 A ，可比较两个输出函数及它们在共同总体上的表现。

数学问题 17.23 学习映射对样本与配置的响应

给定允许的数据变化集合 $\mathcal{U}_D(D)$ 、固定随机数 U 和候选距离 d_H ，能否控制

$$\sup_{D' \in \mathcal{U}_D(D)} d_H(A(D', U), A(D, U))?$$

若方法或目标也变化, 将其作为学习映射的配置参数后, 能否比较两次有限步输出的预测、风险与约束满足情况?

例如, 令 $\mathcal{U}_D(D)$ 包含允许的污染、错标或替换, 并固定干净评价分布 P , 研究

$$\sup_{D' \in \mathcal{U}_D(D)} [R_P(A(D', U)) - R_P(A(D, U))]. \quad (17.14)$$

这描述重训结果的风险增量; 也可以比较指定输入上的决策变化。若关注中间状态或收敛速度, 则回到数学问题 17.18; 若比较理想最优解, 则使用数学问题 17.12。它们都是训练数据改变引出的问题, 却分别研究学习映射、迭代序列与解集映射。训练点影响和投毒造成的最终预测变化属于本处, 固定模型的查询攻击则属于候选函数分析。

重训后的参数接近, 只有经过候选读出和损失的连续性控制, 才能变成预测或风险接近。第 3 章的复合映射分析提供了这条传递路径; 若参数化存在大量等价表示, 也可以绕过参数距离, 直接比较测试点上的损失。这说明“参数稳定”“函数稳定”和“损失稳定”各有自己的对象。

不同用途还会改变比较范围: 单点影响研究一个局部修改, 污染鲁棒性允许一组记录共同改变, 算法稳定性通常规定相邻样本, 并选择逐点、平均或最坏情形标准。压缩、融合和编辑后的能力保持同样需要在共同任务上比较输出。若用理想最优解代替实际模型, 要加入两次训练未达到理想解的误差, 而不能默认优化已经完成。比较优化器时, 也应明确采用共同计算预算还是共同求解精度。参数化可以在表示同一函数类时改变优化几何与有限步输出; 模型编辑则可能只改变类内的某个候选, 不能将这两种修改一律写成候选类变化。

17.3.5.5 发布与遗忘输出的可区分程度

若不固定 U , 应规定两次运行的随机性耦合, 或直接比较给定 D 与 D' 后的输出律。输出函数很接近与随机输出不可区分是不同要求, 隐私和遗忘需要说明观察者能否根据随机结果分清两种数据条件, 并为这种可区分程度规定标准。

数学问题 17.24 随机输出律的可区分程度

给定数据相邻关系、可测发布映射 $M : Z^n \times U \rightarrow W$ 及算法随机变量 U , 令 $M_D = M(D, U)$ 表示随机发布结果。固定相邻数据 D, D' 时, 两个输出律的差异能否满足规定的概率界? 差分隐私要求对所有相邻 D, D' 及输出空间中的每个可测事件 B 都有

$$\mathbb{P}\{M_D \in B\} \leq e^{\epsilon_{\text{priv}}} \mathbb{P}\{M_{D'} \in B\} + \delta_{\text{priv}}.$$

若参照改成删除记录后重新训练的输出律，遗忘机制的输出能否在规定的分布距离或不可区分标准下接近这一参照？

差分隐私 (differential privacy) 的概率来自发布机制随机性，比较时两个数据集固定；数据相邻关系规定保护单位，输出事件规定观察者能够看到的結果。这一条件不同于预测置信度和平均损失稳定性，多次发布也需要单独分析⁵。机器遗忘 (machine unlearning) 以删除记录后重训的输出律为参照，仅降低被删记录上的拟合程度不能证明接近该参照。

比较输出律时，观察者看到的是随机结果，不能只比较两次输出的平均值。若两种机制具有共同支配测度，可以从密度或似然比出发，判断任意事件的概率能相差多少；若目标是接近删除后重训的分布，则应按声明的距离研究耦合或散度。这连接第 3 章的测度积分和第 11 章的分布比较。

多次发布会使观察者获得联合记录，分析对象应随之扩展为完整输出序列，并利用条件分布逐步组合。隐私噪声的尺度、发布次数和可见中间量都在这里进入问题。成员推断或重构攻击可以作为区分两种情况的检验，但攻击失败只能说明该检验没有发现差异，不能替代对所有允许事件的保证。

17.3.6 联合策略、状态转移与轨迹律

第 17.2.6 节的自动散热与资源竞争问题，需要把学习结果放回执行过程。策略执行会进入环境的状态转移。数学对象因此包括联合策略、闭环转移核、随机状态过程及整段轨迹律 $P_{\mathcal{E}}^{\pi}$ 。这些对象描述设备或参与者在环境时间中的行为，与求解策略时产生的计算状态序列不同。

17.3.6.1 观测选择的收益与预算

在自动散热之前，也可能先选择试验负载、请求人工检查或决定下一条标注。动作的直接产物是新证据，历史因而既决定下一个动作，也决定最后学得的模型。

数学问题 17.25 观测选择策略的信息收益与代价

给定允许环境族、观测接口、目标评价律 $P_{\mathcal{E}}$ 、时域 T 及动作成本 $c(a)$ ，策略 π 根据已观察历史 H_t 选择查询 a_t ，终止后由给定学习规则输出 $A(H_T)$ ；所需算法随机性一并计入概率。能否在规定的期望预算

$$\mathbb{E}_{\mathcal{E}}^{\pi} \sum_{t=0}^{T-1} c(a_t) \leq B$$

内, 控制最终风险 $\mathbb{E}_{\mathcal{E}}^{\pi} R_{P_{\mathcal{E}}}(A(H_T))$ 、目标识别错误率, 或交互期间的累计损失? 保证针对固定环境、允许族的最坏情形还是先验平均, 应如何规定?

一次查询的价值可以来自减少目标不确定性, 也可以来自改善最终任务决定, 二者不是同一个量。第 11 章的条件熵与信息量比较前一种变化, 第 15 章的条件决策则将未知回答及后续行动一起纳入评价。实验设计还要借助第 12 章区分观测选择与实际干预。

若每次选择还承担即时成本或收益, 就出现探索与利用的取舍, 可接到数学问题 17.19 的累计表现分析。统计分析应在历史条件下处理数据选择, 核对覆盖、反馈估计和停止规则。对错误标签很自信、反复选择相似记录或重复调用同一来源, 都可能增加记录数量却没有增加所需证据; 因此, 信息获取的保证必须依赖具体查询能力与任务族, 而不能只依赖模型规模。

17.3.6.2 长期价值、稳定与行为约束

自动散热真正运行以后, 我们关心的是温度是否长期可控、是否越过安全线, 以及总成本有多大。这些要求作用于执行轨迹, 不能只靠训练损失或单步预测来评价。

数学问题 17.26 闭环轨迹能否满足长期要求

给定环境 $\mathcal{E}$ 、可得信息结构、策略 π 及允许轨迹集合 $\mathcal{S}$, 由策略诱导的轨迹律 $P_{\mathcal{E}}^{\pi}$ 是否满足

$$\mathbb{P}_{\tau \sim P_{\mathcal{E}}^{\pi}}\{\tau \in \mathcal{S}\} \geq 1 - \alpha,$$

或更强的逐轨迹约束? 累计成本、到达概率或长期状态是否满足指定要求, 学习与模型估计误差会使这些量改变多少?

单步预测校准和训练收敛不能直接替代这个结论。闭环还可研究长期分布、状态稳定性和允许集合是否保持, 具体命题需保留观测信息、行动时序及环境假设。离线学习得到的策略, 则要先检查既有轨迹能否支持执行效果的估计。

闭环分析需要把预测结果继续传到动作和后继状态。对确定性闭环, 若关心状态是否回到工作区间, 可以在线性系统中看谱, 在非线性系统中寻找随运行下降的 Lyapunov 函数, 连接第 13、14 章。若要求始终不越界, 则要研究允许集合能否在每次转移下保持; 平均成本低不能替代这一要求。存在持续随机扰动时, 须将其计入转移核, 再研究适当的矩、概率或路径

性质；没有扰动时的稳定性，不能直接保证随机轨迹逐条趋于平衡点或以高概率始终安全。

评价累计成本时，则要把当前成本与未来成本相加。在状态包含必要信息的条件下，先计算给定下一状态的未来成本，再对下一状态取条件期望，就得到第 15 章的 Bellman 递推。有限时域可向后计算；有限状态、有界成本和折扣因子小于 1 时，可研究相应算子的压缩性。部分观测时还需要信念更新或状态估计；风险敏感和最坏情形目标，则必须核对时间一致性及不确定集合能否按阶段分解。真实轨迹可以含不可见状态，因此还要说明要求能否由实际记录验证，或需要怎样的环境模型和状态估计。由有限数据估计的训练约束是否意味着真实环境中的可行性，属于统计证据与闭环保证之间的联系。

17.3.6.3 环境或策略变化后的执行响应

可以比较固定策略在 $\mathcal{E}$ 与 $\mathcal{E}'$ 中的轨迹律，也可以比较同一环境中 π 与 π' 诱导的状态偏差、越界概率和累计成本。小预测误差是否经反馈累积，是闭环转移的性质；学习参数序列对数据的稳定性本身不足以回答它。执行攻击改变实际动作或转移规律时，也要在这类对象上规定扰动范围。

数学问题 17.27 闭环过程对环境与策略变化的响应

给定共同轨迹空间上的两种执行设定 $(\mathcal{E}, \pi)$ 与 $(\mathcal{E}', \pi')$ ，相应轨迹律记为 $P_{\mathcal{E}}^{\pi}$ 与 $P_{\mathcal{E}'}^{\pi'}$ 。对指定事件类 $\mathcal{B}$ 或累计成本函数 $C(\tau)$ ，能否控制

$$\sup_{B \in \mathcal{B}} |P_{\mathcal{E}'}^{\pi'}(B) - P_{\mathcal{E}}^{\pi}(B)|,$$

$$|\mathbb{E}_{P_{\mathcal{E}'}^{\pi'}} C - \mathbb{E}_{P_{\mathcal{E}}^{\pi}} C|?$$

若比较两条具体状态轨迹，应规定初值和外部随机性的耦合，再评价轨迹距离。

闭环扰动可能被反复反馈。例如，略高的温度预测改变散热动作，动作又改变下一次温度与输入。因此，先在明确的初值和噪声耦合下比较一步转移，再研究偏差如何沿轨迹传播，才能使用第 13.3、14.3 节的敏感性与扰动抑制工具。这里控制的是执行状态，不是训练参数。

状态距离较小，还需要经过最后一层转换才能解释为成本或安全改善。平滑成本可以利用连续性；越界事件在边界附近可能因很小变化而翻转，需要额外的边界概率或安全余量条件。模拟模型、观测器和策略近似各自造成的误差，都应沿这条链检查，不能由单步预测精度直接宣称长期行为可靠。

17.3.6.4 均衡存在与学习能否达到

多方各有目标时，先给出各自可行策略和损失，再判断是否存在没有单方改进空间的联合策略。

数学问题 17.28 多方响应能否达到所求均衡

给定各方可行策略、损失 $R_i(\pi_i, \pi_{-i})$ 及响应或学习规则，是否存在联合策略 π^* ，使每方都不能通过单方改变降低自己的损失，即

$$R_i(\pi_i^*, \pi_{-i}^*) \leq R_i(\pi_i, \pi_{-i}^*)$$

对每方 i 及其所有可行 π_i 成立？学习产生的联合状态序列能否趋近这种条件？

其中 π_{-i} 表示除第 i 方以外的其他策略。均衡存在性是联合策略和各方目标的性质；某个学习规则是否到达均衡，则将该规则产生的联合状态交给更新算子与序列分析。合作、零和与一般和设定会改变所求条件，不能把共同损失下降一律解释成达到均衡。

均衡存在性的核心是：给定其他方行为，每一方有哪些最优响应，这些响应能否同时相容。在有限混合策略博弈中，策略位于紧凸单纯形上，最佳响应是集值映射，这解释了第 16 章为什么使用不动点工具。零和结构还允许通过极小极大与线性规划对偶研究双方的保证值。

如果问题改为“反复学习会不会到达均衡”，对象已经变成联合更新序列，要重新分析其谱、势函数或遗憾。相关均衡允许共同信号，贝叶斯博弈还保留私有类型；它们规定的允许偏离和所取期望不同，不能只套上面的 Nash 式。拍卖或资源分配机制进一步把规则作为设计变量，以激励约束限制参与者的偏离收益，再研究规则诱导的结果。

17.3.7 对象与分析问题的交叉对应

一个对象可以接受多种分析，每个分析问题又可能有多条条件不同的方法。表 17.3 按这两层关系组织前面的问题：先选数学对象，再选所求性质，随后核对相应方法的条件和前文依据。本表沿用表 17.2 中的对象与问题名称及编号。前一张表从机器学习任务寻找所需数学问题，本表从这些问题寻找条件适合的数学方法；二者通过问题编号连接，同一数学问题可以出现在多个机器学习任务下。相关知识后的位置精确到前文节或小节，可以回到那里检查定义、假设与已证明的结果。

例如，错误训练记录引起的解集变化、轨迹变化和最终预测变化，分别研究 S 、 $(v_D^{(k)})_k$ 和 A 。它们都可作扰动分析，但各有自己的距离、有效区域

及误差传递关系。同样，迭代序列还可以研究极限、速度与累计表现，不能只归入一种收敛问题。

数学对象	数学问题	相关知识
观测核、概率测度与经验测度 $K, P, Q_n, \hat{P}_D$	目标的可识别性(问题 17.1)	观测等价类与目标恒定性；目标须在每个观测等价类中取同一值(第 1.1.2、10.5.1.1 节) 线性观测用零空间查找歧义；干预目标另需交换性与支持条件(第 6.3、12.4 节)
	经验积分的一致估计(问题 17.2)	样本独立同分布于所估总体、损失统一有界时，用集中与有限候选联合界(第 10.4.2.1、10.4.2.2 节) 样本独立同分布于所估总体，损失误差可由覆盖距离传递时，用有限覆盖与独立副本对称化(第 5.2.3、10.4.2.2 节)
	来源观测与目标风险的连接(问题 17.3)	目标对来源绝对连续且密度比可确定时换测度；方差控制另需二阶矩(第 10.3.3、10.4.2.3 节) 检验来源观测等价类上的目标唯一性；行动效果另核对交换性与支持(第 10.5.1.1、12.4 节)
	观测律与风险积分的扰动(问题 17.4)	有界损失用总变差；Lipschitz 损失与有限一阶矩用 Wasserstein 耦合界(第 11.3.1 节) 核积分与联合分布分析；核须可测，样本依赖保留在联合律中(第 10.2.2.2、10.2.1 节)
	覆盖、校准与条件风险(问题 17.5)	在指定联合总体上用条件期望与适当评分分析校准(第 10.2.2.1、10.5.3.1 节) 条件于训练信息，校准记录与新记录可交换且评分固定或对称构造时，用秩控制覆盖；多次选择另控联合错误事件(第 10.5.3.2、10.5.4.3 节)
	条件化、积分与生成(问题 17.6)	给定条件核可条件化；有限取值变量的局部分解用消元，树或合法树分解上用消息(第 10.2.2.2、9.5.2 节) 支持与积分条件成立时用 KL 变分分解；采样方差另需二阶矩(第 11.4.1.3、10.4.2.3 节)

续下页

表 17.3 (续)

数学对象	数学问题	相关知识
候选函数、函数类与表示映射 $h, \mathcal{H}, \Phi$	精确表示与最佳逼近 (问题 17.7)	在实际参数化的像上判断表示; 线性情形检查列空间与秩 (第 1.2.1、6.3 节) Hilbert 范数下的非空闭凸候选集用投影; 矩阵给定秩预算及谱或 Frobenius 范数时用截断 SVD (第 5.2、6.5 节)
	固定函数的输入响应与分布风险 (问题 17.8)	线性映射用算子范数; 非线性区域响应用导数及 Taylor 余项 (第 6.2.3、3.3.4 节) 固定候选与损失后, 按有界性或 Lipschitz 和矩条件比较分布风险 (第 11.3.1 节)
	对称结构与信息保留 (问题 17.9)	指定两端群作用, 用轨道与商映射检验不变性、等变性及因子化 (第 7.1.3 节) 线性压缩检查零空间; 图上滤波检查谱模态与重编号等变性 (第 6.3、9.5.1 节)
目标泛函、可行集与解集映射 $F, \mathcal{X}, S$	可行性、极值存在与最优条件 (问题 17.10)	非空紧域上的连续极值; 有限维非空闭域上, 适当目标用下半连续与强制性 (第 3.3.1、4.1.2 节) 凸性支持整体判优; 约束资格条件下用 KKT, 严格凸性支持唯一性 (第 4.1.3、4.4.3.1 节)
	代理目标与任务目标的关系 (问题 17.11)	同一条件标签律下比较评分与条件风险, 再经条件期望传到总体 (第 10.2.2.1、10.5.3.1 节) 概率目标用对数评分、KL 或 ELBO 差距; 核对支持和可积性 (第 11.2.1、11.4.1.3 节)
	最优值与解集的敏感性 (问题 17.12)	光滑解方程的 Jacobian 可逆时, 用隐函数与局部条件数 (第 3.3.5、6.6 节) 活动约束固定且 KKT 导数可逆时, 用乘子及解分支敏感性 (第 4.4.3.4 节)
	多目标、尾部风险与取舍 (问题 17.13)	Pareto 比较、标量化与约束; 非凸前沿不能只靠加权和覆盖 (第 4.6.1、4.4.3.1 节) 给定随机损失后选择风险泛函; 动态风险还须检查时间一致性 (第 15.2、15.2.4 节)
	内外层优化及内层误差 (问题 17.14)	有限步更新可微时展开并用链式求导; 保留配置的全部依赖 (第 3.3.2、4.6.3 节) 内层解分支非退化时用隐式超梯度; 随机求导交换另需可积支配 (第 4.6.3、3.5.4 节)

续下页

表 17.3 (续)

数学对象	数学问题	相关知识
计算算子与迭代序列 $C, T_{D,k}, (v^{(k)})_k$	计算正确性、近似误差与资源 (问题 17.15)	有限取值变量具有局部分解时, 用消元不变量与归纳证明检查正确性 (第 9.5.2 节) 指定输入、范数与浮点模型后比较前后向误差及条件数 (第 6.6.1 节) 规定编码、计算模型与精度后计数时间、空间和查询成本 (第 2.3 节)
	极限、选解与收敛速度 (问题 17.16)	固定更新为完备空间上的压缩自映射时, 用不动点与停止误差 (第 3.2.3.1 节) 梯度 Lipschitz 与适当步长下用下降引理; 凸或 PL 条件支持最优值差 (第 4.2 节) 固定线性更新用矩阵幂与谱; 另查非正规暂态 (第 6.4 节)
	不变律、分布极限与积分误差 (问题 17.17)	有限不可约 Markov 链用遍历平均; 分布收敛另需非周期 (第 10.4.6.2 节) 选定测度距离; 平稳均值方差保留自相关及其可和条件 (第 11.2.3、10.4 节)
	数据或更新改变后的轨迹响应 (问题 17.18)	共同有效区域内, 用一步 Lipschitz 界展开误差递推 (第 3.2、4.5.4 节) 连续时间状态与输入正则时, 用 Grönwall 与受迫响应 (第 13.3 节)
	跟踪与相对比较者的累计表现 (问题 17.19)	闭凸有界域、凸损失与受控真次梯度下, 用投影及距离势函数 (第 16.5.2 节) 历史条件无偏且增量受控时用鞅差; 平均策略保证另核对博弈结构 (第 10.4.5.3、16.5.4 节)

续下页

表 17.3 (续)

数学对象	数学问题	相关知识
$\hat{J}_n, A, \Lambda_D$ 学习映射与随机输出律	统计恢复与一致性 (问题 17.20)	分离的总体最优、经验准则一致收敛与求解误差消失支持 M 估计一致性 (第 10.5.2 节) 自伴矩阵、受控扰动及谱隙下用谱扰动和子空间距离 (第 6.6.3 节)
	数据依赖输出的泛化与超额风险 (问题 17.21)	静态 i.i.d. 有界损失下用一致误差和 ERM 比较, 并保留求解误差 (第 10.4.2.2、4.2 节) 静态 i.i.d. 有界损失与有限样本—输出互信息下, 控制平均有符号泛化差 (第 11.3.2.1 节) 静态 i.i.d. 有界损失、独立先验、候选绝对连续及预先固定参数下, 用 PAC-Bayes 界 (第 11.3.2.2 节) 目标风险有已知加权表示时, i.i.d. 来源样本、抽样前固定的有限候选类及统一有界加权损失支持换测度与共同误差 (第 10.3.3、10.4.2.2 节)
	统一学习规则的存在与复杂度 (问题 17.22)	预先规定允许分布族, 用函数类规模与分布无关共同误差构造规则 (第 5.2.3、10.4 节) 目标分离而观测难区分时, 用检验与信息下界排除统一保证 (第 11.2.4 节) 规定访问与编码后另查停机性、查询及实现成本 (第 2.3 节)
	重新学习后的预测与风险响应 (问题 17.23)	共同随机索引、光滑有界样本梯度等条件下, 用耦合 SGD 样本替换界 (第 4.5.4 节) 读出与损失具有区域正则性时, 用复合映射将参数差传到行为或风险 (第 3.3 节)
	发布与遗忘输出的可区分程度 (问题 17.24)	在共同发布空间上按绝对连续性定义密度比, 比较事件或散度 (第 10.1.2、11.2.3 节) 条件绝对连续及可积性下按实际历史平均累积 KL; Rényi 组合另需逐历史统一散度界 (第 11.2.4.2 节)

续下页

表 17.3 (续)

数学对象	数学问题	相关知识
联合策略、状态转移与轨迹律 $\pi, T, P_\varepsilon^\pi$	观测选择的收益与预算 (问题 17.25)	规定信号核及有限行动、可积损失, 用条件决策比较信息价值与成本 (第 15.4.4 节) 规定抽样与噪声条件, 用预算分配、设计矩阵和自适应轨迹信息 (第 10.5.5.2、11.2.4.2 节)
	长期价值、稳定与行为约束 (问题 17.26)	有限状态行动、有界成本及折扣小于 1 时, 用 Bellman 压缩; 有限时域保留终端条件 (第 15.3 节) 确定性适定闭环用 Lyapunov 与不变集合; 随机扰动另需矩或概率控制 (第 14.2、14.4 节)
	环境或策略变化后的执行响应 (问题 17.27)	共同初值与噪声耦合、有效区域正则性下, 用轨迹敏感性和受迫响应 (第 13.3、14.3 节) 事件及有界成本用总变差; Lipschitz 成本与有限一阶矩用 Wasserstein, 分别比较概率或期望 (第 11.3.1 节)
	均衡存在与学习能否达到 (问题 17.28)	紧凸策略域与相应最佳响应条件下, 用集合值不动点; 零和用对偶 (第 16.3.2.2、16.3.3 节) 可微响应在内点不动点处用 Jacobian 谱检验局部稳定 (第 16.4.2 节) 规定遗憾与允许偏离后分析平均均衡误差; 不据此推断末轮收敛 (第 16.5.4 节)

表 17.3 数学对象、分析问题与前文知识的对应。对象单元格合并同一对象上的问题, 问题单元格合并同一问题的不同分析路线; 括号给出前文节或小节位置。每条方法都依赖所列条件; 应用到具体学习模型时, 还须证明这些条件成立, 并推导相应结论。

这些联系说明后续分析应核对哪些条件、可以调用哪些工具。同一个训练扰动问题可能连接分析、线性代数、优化与概率知识; 具体条件能否成立、能得到何种界或算法结论, 需要回到后续章节的模型与场景中证明。例如, 判断一个网络能否用于高负载预警, 需要先检查候选范围能否表达温度规律, 再检查采样记录能否支持高负载下的误差估计, 最后检查更新规则能否求得所需候选。只有这些具体条件确定以后, 本节的表示、泛化与收敛问题才有可以验证的结论。

17.4 本章小结

学习设定由数据、目标和方法组成。静态环境是带概率规律的情形空间, 观测核规定给定情形后记录怎样产生, 采样机制再规定整批记录的联合律。损失与约束定义要求, 候选类、参数化、目标构造和优化规则决定怎样从有限数据得到结果。交互任务还需转移核与策略, 由它们共同诱导轨迹分布。

候选能否表达目标规律、训练能否求得合格候选、新记录上的误差是否可控、实际执行是否可靠,是四个需要分别回答的问题。观测核与概率测度、候选函数、目标泛函与解集、计算算子与序列、学习映射、闭环轨迹,各自都可以接受不止一种分析。迭代序列既可研究收敛与计算误差,也可研究数据或更新变化引起的轨迹偏差;理想解与有限步输出的变化则分别属于解集映射和学习映射。训练与测试分布不同时,固定训练问题仍可收敛,但其解在目标分布上的表现需要来源与目标之间的额外联系。迁移任务要规定共享信息与目标评价,离策略学习还要区分行为策略与候选策略诱导的轨迹律;在线反馈则使之后的数据依赖已有学习结果。

数据、方法或目标改变后,许多研究问题可以归入同一个扰动响应框架。推理时研究 $x \mapsto h_D(x)$, 重训时研究 $D \mapsto A(D, U)$, 改变方法或目标时则研究配置进入学习映射后的结果。它们共享比较输入变化与输出变化的思路,却不能共用未经检查的扰动集合、距离或概率条件。局部输入稳定也不自动保证跨分布风险,训练稳定也不自动保证任务已经学好。

从实际任务到数学问题,应写清给定对象、允许变化、比较基准和所求结论,再根据空间结构、光滑性、凸性、采样依赖与反馈条件,联系相应的数学知识。紧性与极值、投影与逼近、压缩与迭代、条件期望与统计、反馈与轨迹,提供不同的分析入口。具体工具能否适用、能得到什么保证,仍须在相应模型和场景中核对条件并完成论证。这种表述使我们能够看清不同任务共有的数学困难,也能看清每项结论成立的条件。训练误差很小、测试均值很好或算法已经收敛,都只回答了其中一部分问题;是否满足实际应用的全部要求,仍需沿数据、目标、学习和执行的各个环节逐一论证。



参考文献

- C. C. Aggarwal, *Recommender Systems*, Springer, 2016.
- S.-i. Amari, *Natural Gradient Works Efficiently in Learning* In *Neural Computation*, 1998, vol. 10, no. 2, pp. 251–276.
- A. D. Ames, X. Xu, J. W. Grizzle, P. Tabuada, *Control Barrier Function Based Quadratic Programs for Safety Critical Systems* In *IEEE Transactions on Automatic Control*, 2017, vol. 62, no. 8, pp. 3861–3876.
- B. D. O. Anderson, J. B. Moore, *Optimal Control: Linear Quadratic Methods*, Dover Publications, 2007.
- N. Aronszajn, *Theory of Reproducing Kernels* In *Transactions of the American Mathematical Society*, 1950, vol. 68, no. 3, pp. 337–404.
- S. Axler, *Linear Algebra Done Right*, Springer, 2015, 3rd ed.
- M. Bardi, I. Capuzzo-Dolcetta, *Optimal Control and Viscosity Solutions of Hamilton–Jacobi–Bellman Equations*, Birkhäuser, 1997.
- J. Baxter, *A Model of Inductive Bias Learning* In *Journal of Artificial Intelligence Research*, 2000, vol. 12, pp. 149–198.
- S. Ben-David, J. Blitzer, K. Crammer, A. Kulesza, F. Pereira, J. W. Vaughan, *A Theory of Learning from Different Domains* In *Machine Learning*, 2010, vol. 79, pp. 151–175.
- Y. Benjamini, Y. Hochberg, *Controlling the False Discovery Rate: A Practical and Powerful Approach to Multiple Testing* In *Journal of the Royal Statistical Society: Series B (Methodological)*, 1995, vol. 57, no. 1, pp. 289–300.
- C. M. Bishop, *Pattern Recognition and Machine Learning*, Springer, 2006, 1st ed.
- C. M. Bishop, H. Bishop, *Deep Learning: Foundations and Concepts*, Springer, 2024.
- V. S. Borkar, *Stochastic Approximation: A Dynamical Systems Viewpoint*, Cambridge University Press, 2008.
- N. Boumal, *An Introduction to Optimization on Smooth Manifolds*, Cambridge University Press, 2023.

- S. Boyd, L. Vandenberghe, *Convex Optimization*, Cambridge University Press, 2004.
- D. M. Chickering, *Optimal Structure Identification with Greedy Search* In Journal of Machine Learning Research, 2002, vol. 3, pp. 507–554.
- F. R. K. Chung, *Spectral Graph Theory*, American Mathematical Society, 1997, 1st ed.
- J. B. Conway, *A Course in Functional Analysis*, Springer, 1990, 2nd ed.
- S. A. Cook, *The Complexity of Theorem-Proving Procedures* In Proceedings of the Third Annual ACM Symposium on Theory of Computing, 1971, pp. 151–158.
- J. W. Cooley, J. W. Tukey, *An Algorithm for the Machine Calculation of Complex Fourier Series* In Mathematics of Computation, 1965, vol. 19, no. 90, pp. 297–301.
- T. H. Cormen, C. E. Leiserson, R. L. Rivest, C. Stein, *Introduction to Algorithms*, MIT Press, 2022, 4th ed.
- T. M. Cover, J. A. Thomas, *Elements of Information Theory*, Wiley, 2006, 2nd ed.
- M. P. Deisenroth, A. A. Faisal, C. S. Ong, *Mathematics for Machine Learning*, Cambridge University Press, 2020.
- R. Diestel, *Graph Theory*, Springer, 2017, 5th ed.
- C. Dwork, A. Roth, *The Algorithmic Foundations of Differential Privacy* In Foundations and Trends in Theoretical Computer Science, 2014, vol. 9, no. 3–4, pp. 211–407.
- C. Eckart, G. Young, *The Approximation of One Matrix by Another of Lower Rank* In Psychometrika, 1936, vol. 1, no. 3, pp. 211–218.
- G. B. Folland, *Real Analysis: Modern Techniques and Their Applications*, Wiley, 1999, 2nd ed.
- A. Géron, *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow*, O'Reilly Media, 2022, 3rd ed.
- G. H. Golub, C. F. Van Loan, *Matrix Computations*, Johns Hopkins University Press, 2013, 4th ed.
- I. Goodfellow, Y. Bengio, A. Courville, *Deep Learning*, MIT Press, 2016.
- R. L. Graham, D. E. Knuth, O. Patashnik, *Concrete Mathematics: A Foundation for Computer Science*, Addison-Wesley, 1994, 2nd ed.
- E. Hairer, S. P. Nørsett, G. Wanner, *Solving Ordinary Differential Equations I: Nonstiff Problems*, Springer, 1993, 2nd ed.
- T. Hastie, R. Tibshirani, J. Friedman, *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*, Springer, 2009, 2nd ed.

- M. A. Hernán, J. M. Robins, *Causal Inference: What If*, Chapman & Hall/CRC, 2020.
- R. A. Horn, C. R. Johnson, *Matrix Analysis*, Cambridge University Press, 2013, 2nd ed.
- C. Huyen, *Designing Machine Learning Systems*, O'Reilly Media, 2022.
- G. James, D. Witten, T. Hastie, R. Tibshirani, *An Introduction to Statistical Learning*, Springer, 2021, 2nd ed.
- D. Jurafsky, J. H. Martin, *Speech and Language Processing*, Prentice Hall, 2009, 2nd ed.
- S. Kakutani, *A Generalization of Brouwer's Fixed Point Theorem* In Duke Mathematical Journal, 1941, vol. 8, no. 3, pp. 457–459.
- O. Kallenberg, *Foundations of Modern Probability*, Springer, 2021, 3rd ed.
- R. E. Kalman, *A New Approach to Linear Filtering and Prediction Problems* In Journal of Basic Engineering, 1960, vol. 82, no. 1, pp. 35–45.
- H. K. Khalil, *Nonlinear Systems*, Prentice Hall, 2002, 3rd ed.
- M. Kleppmann, C. Riccomini, *Designing Data-Intensive Applications*, O'Reilly Media, 2026, 2nd ed.
- P. E. Kloeden, E. Platen, *Numerical Solution of Stochastic Differential Equations*, Springer, 1992.
- D. E. Knuth, *The Art of Computer Programming, Volume 2: Seminumerical Algorithms*, Addison-Wesley, 1997, 3rd ed.
- D. Koller, N. Friedman, *Probabilistic Graphical Models: Principles and Techniques*, MIT Press, 2009.
- V. Kolmogorov, R. Zabih, *What Energy Functions Can Be Minimized via Graph Cuts?* In IEEE Transactions on Pattern Analysis and Machine Intelligence, 2004, vol. 26, no. 2, pp. 147–159.
- J. M. Lee, *Introduction to Riemannian Manifolds*, Springer, 2018, 2nd ed.
- J. M. Lee, *Introduction to Smooth Manifolds*, Springer, 2013, 2nd ed.
- E. L. Lehmann, J. P. Romano, *Testing Statistical Hypotheses*, Springer, 2005, 3rd ed.
- M. Leshno, V. Y. Lin, A. Pinkus, S. Schocken, *Multilayer Feedforward Networks with a Nonpolynomial Activation Function Can Approximate Any Function* In Neural Networks, 1993, vol. 6, no. 6, pp. 861–867.
- S. Levine, A. Kumar, G. Tucker, J. Fu, *Offline Reinforcement Learning: Tutorial, Review, and Perspectives on Open Problems* In arXiv preprint arXiv:2005.01643, 2020.
- C. D. Manning, P. Raghavan, H. Schütze, *Introduction to Information Retrieval*, Cambridge University Press, 2008.

- J. Mercer, *Functions of Positive and Negative Type, and Their Connection with the Theory of Integral Equations* In Philosophical Transactions of the Royal Society of London, Series A, 1909, vol. 209, pp. 415–446.
- S. P. Meyn, R. L. Tweedie, *Markov Chains and Stochastic Stability*, Cambridge University Press, 2009, 2nd ed.
- T. M. Mitchell, *Machine Learning*, McGraw-Hill, 1997, 1st ed.
- M. Mohri, A. Rostamizadeh, A. Talwalkar, *Foundations of Machine Learning*, The MIT Press, 2018, 2nd ed.
- K. P. Murphy, *Machine Learning: A Probabilistic Perspective*, MIT Press, 2012.
- K. P. Murphy, *Probabilistic Machine Learning*, The MIT Press, 2023.
- K. P. Murphy, *Probabilistic Machine Learning: An Introduction*, MIT Press, 2022.
- J. Nash, *Non-Cooperative Games* In The Annals of Mathematics, 1951, vol. 54, no. 2, pp. 286–295.
- G. L. Nemhauser, L. A. Wolsey, M. L. Fisher, *An Analysis of Approximations for Maximizing Submodular Set Functions—I* In Mathematical Programming, 1978, vol. 14, pp. 265–294.
- J. Nocedal, S. J. Wright, *Numerical Optimization*, Springer, 2006, 2nd ed.
- B. Øksendal, *Stochastic Differential Equations: An Introduction with Applications*, Springer, 2003, 6th ed.
- J. Pearl, *Causality: Models, Reasoning, and Inference*, Cambridge University Press, 2009, 2nd ed.
- M. L. Puterman, *Markov Decision Processes: Discrete Stochastic Dynamic Programming*, Wiley, 1994.
- C. E. Rasmussen, C. K. I. Williams, *Gaussian Processes for Machine Learning*, MIT Press, 2006.
- H. E. Rauch, F. Tung, C. T. Striebel, *Maximum Likelihood Estimates of Linear Dynamic Systems* In AIAA Journal, 1965, vol. 3, no. 8, pp. 1445–1450.
- H. Robbins, S. Monro, *A Stochastic Approximation Method* In The Annals of Mathematical Statistics, 1951, vol. 22, no. 3, pp. 400–407.
- R. T. Rockafellar, S. Uryasev, *Optimization of Conditional Value-at-Risk* In The Journal of Risk, 2000, vol. 2, no. 3, pp. 21–41.
- D. B. Rubin, *Inference and Missing Data* In Biometrika, 1976, vol. 63, no. 3, pp. 581–592.
- A. Ruszczyński, *Risk-Averse Dynamic Programming for Markov Decision Processes* In Mathematical Programming, 2010, vol. 125, no. 2, pp. 235–261.
- B. Schölkopf, R. Herbrich, A. J. Smola, *A Generalized Representer Theorem* In Computational Learning Theory, 2001, pp. 416–426.

- S. Shalev-Shwartz, S. Ben-David, *Understanding Machine Learning: From Theory to Algorithms*, Cambridge University Press, 2014, 1st ed.
- L. S. Shapley, “A Value for n -Person Games”, in: *Contributions to the Theory of Games II*, ed. by H. W. Kuhn, A. W. Tucker, vol. 28, Annals of Mathematics Studies, Princeton University Press, 1953, pp. 307–318.
- R. S. Sutton, A. G. Barto, *Reinforcement Learning: An Introduction*, MIT Press, 2018, 2nd ed.
- R. Szeliski, *Computer Vision*, Springer, 2022, 2nd ed.
- C. Szepesvári, *Algorithms for Reinforcement Learning*, Morgan & Claypool Publishers, 2010.
- A. M. Turing, *On Computable Numbers, with an Application to the Entscheidungsproblem* In Proceedings of the London Mathematical Society, 1937, vol. 42, no. 1, pp. 230–265.
- A. W. van der Vaart, *Asymptotic Statistics*, Cambridge University Press, 1998.
- C. Villani, *Optimal Transport: Old and New*, Springer, 2009.
- S. Winograd, *Arithmetic Complexity of Computations*, Society for Industrial and Applied Mathematics, 1980.
- A. Zhang, Z. C. Lipton, M. Li, A. J. Smola, *Dive into Deep Learning*, Cambridge University Press, 2023.
- M. Zinkevich, *Online Convex Programming and Generalized Infinitesimal Gradient Ascent* In Proceedings of the Twentieth International Conference on Machine Learning, 2003, pp. 928–936.
- M. Zinkevich, M. Johanson, M. Bowling, C. Piccione, *Regret Minimization in Games with Incomplete Information* In Advances in Neural Information Processing Systems, 2007, pp. 1729–1736.
- 周志华, 机器学习, 清华大学出版社, 2016, 1st ed.
- 李航, 统计学习方法, 清华大学出版社, 2019, 2nd ed.
- 邱锡鹏, 神经网络与深度学习, 机械工业出版社, 2020.

索引

- 3-SAT, 50
- μ 强凸, μ -strongly convex, 137
- 一致, consistent, 555
- 一致可积, uniformly integrable, 499
- 一致性, consistency, 627
- 一致收敛, uniform convergence, 484
- 一致紧的, uniformly tight, 503
- 一致连续, uniformly continuous, 86
- 一般和博弈, general-sum game, 803
- 一阶可行方向, linearized feasible direction, 158
- 三角不等式, triangle inequality, 247
- 上半连续, upper hemicontinuous, 811
- 上确界, supremum, 11
- 下半连续, lower semicontinuous, 134
- 下确界, infimum, 11
- 下采样, downsampling, 384
- 不变, invariant, 310
- 不变子空间, invariant subspace, 270
- 不变集, invariant set, 679
- 不可约性, irreducibility, 522
- 不可行, infeasible, 132
- 个体处理效应, individual treatment effect, 628
- 中介变量, mediator, 651
- 中值定理, mean value theorem, 94
- 主动学习, active learning, 576
- 主化-最小化方法, majorization-minimization, 175
- 主成分分析, principal component analysis, 286
- 主角, principal angles, 296
- 乘积测度, product measure, 111
- 二元关系, binary relation, 5
- 二部图, bipartite graph, 393
- 二阶平稳, second-order stationarity, 521
- 二项分布, binomial distribution, 454
- 互信息, mutual information, 585
- 互相关, cross-correlation, 378
- 交叉熵, cross-entropy, 583
- 交叉验证, cross-validation, 559
- 交替最小化, alternating minimization, 177
- σ 代数, sigma-algebra, 72
- 仿射包, affine hull, 168
- 优化问题, optimization problem, 61
- 伪多项式时间算法, pseudo-polynomial-time algorithm, 60
- 伪打散, pseudo-shattering, 47
- 伪真参数, pseudo-true parameter, 543
- 伪维, pseudo-dimension, 48
- 伪距离, pseudometric, 71
- 估计值, estimate, 535
- 估计量, estimator, 535
- 似然, likelihood, 540
- 余切空间, cotangent space, 320
- 信念状态, belief state, 787
- 信息集, information set, 798
- 熵, entropy, 579
- 牛顿法, Newton's method, 145
- 特征值, eigenvalue, 270
- 特征向量, eigenvector, 270
- 特征多项式, characteristic polynomial, 270
- 状态转移矩阵, state transition matrix, 670
- 独立, independent, 470
- 环, cycle, 396
- 生成树, spanning tree, 407
- 目标总体, target population, 536
- 相关均衡, correlated equilibrium, 817
- 相对内部, relative interior, 168
- 相对熵, relative entropy, 583
- 相对阶, relative degree, 752
- 相干风险, coherent risk measure, 759
- 矩形性, rectangularity, 771
- 矩母函数, moment-generating function, 452
- 矩阵博弈, matrix game, 796

- 矩阵范数, matrix norm, 256
- 硬约束, hard constraint, 50
- 碰撞点, collider, 651
- 祖先, ancestor, 397
- 祖先图, ancestral graph, 403
- 祖先闭包, ancestral closure, 403
- 离散代数 Riccati 方程, discrete algebraic Riccati equation, 735
- 离散傅里叶变换, discrete Fourier transform, 358
- 离散卷积, discrete convolution, 371
- 离散时间信号, discrete-time signal, 352
- 离散时间傅里叶变换, discrete-time Fourier transform, 361
- 秩, rank, 259
- 积分概率度量, integral probability metric, 590
- 积分调节, integral regulation, 741
- 稳定, stable, 679
- 稳定化解, stabilizing solution, 735
- 稳定秩, stable rank, 288
- 笛卡尔积, Cartesian product, 5
- 等价关系, equivalence relation, 6
- 等价类, equivalence class, 6
- 等变, equivariant, 311
- 简单函数, simple function, 105
- 算法稳定性, algorithmic stability, 181
- 粗相关均衡, coarse correlated equilibrium, 817
- 紧的, tight, 503
- 紧致, compact, 87
- 累积量生成函数, cumulant-generating function, 452
- 约束资格条件, constraint qualification, 159
- 纯策略, pure strategy, 797
- 线性二次调节, linear-quadratic regulation, 732
- 线性子空间, linear subspace, 244
- 线性无关, linearly independent, 244
- 线性映射, linear map, 251
- 线性组合, linear combination, 244
- 线性表示, linear representation, 310
- 组合图拉普拉斯, combinatorial graph Laplacian, 420
- 细致平衡, detailed balance, 511
- 经验 Rademacher 复杂度, empirical Rademacher complexity, 488
- 经验风险, empirical risk, 848
- 经验风险最小化, empirical risk minimization, 848
- 结构因果模型, structural causal model, 648
- 绝对可积, absolutely integrable, 109
- 绝对收敛, absolutely converge, 79
- 绝对连续, absolutely continuous, 122, 449
- 绝对连续曲线, absolutely continuous curve, 667
- 统计模型, statistical model, 535
- 统计量, statistic, 535
- 维度重排, permutation of axes, 246
- 维数, dimension, 245
- 置信区间, confidence interval, 560, 647
- 置信序列, confidence sequence, 564, 571
- 置换检验, permutation test, 570
- 群, group, 309
- 群作用, group action, 309
- 耦合, coupling, 592
- 联合可利用度, joint exploitability, 840
- 联络, connection, 327
- 胖打散, fat-shattering, 48
- 胖打散维, fat-shattering dimension, 48
- 脉冲响应, impulse response, 370
- 自信息, self-information, 579
- 自归一化, self-normalized, 519
- 自然参数, natural parameter, 458
- 自然梯度, natural gradient, 619
- 自相关有效样本量, autocorrelation effective sample size, 526
- 范数, norm, 247
- 范畴, category, 317
- 蕴含, implication, 17
- 虚设参与者性质, dummy player property, 805
- 行为策略, behavior strategy, 799
- 行列式, determinant, 252
- 行动补救, algorithmic recourse, 635
- 行空间, row space, 259
- 补偿泊松过程, compensated Poisson process, 528
- 覆盖率, coverage, 775
- 覆盖边, covered edge, 656
- 证书, certificate, 64
- 证据下界, evidence lower bound, 609
- 评价 σ 代数, evaluation sigma-algebra, 476
- 评分规则, scoring rule, 550
- 识别集合, identified set, 642
- 诱导子图, induced subgraph, 393
- 诱导宽度, induced width, 407
- 诱导的算子范数, induced operator norm, 95
- 诱导矩阵范数, induced matrix norm, 256
- 调节, regulation, 739
- 谱半径, spectral radius, 274
- 谱范数, spectral norm, 256
- 赋值, assignment, 20
- 赋范空间, normed space, 191
- 超图, hypergraph, 393

- 跟踪, tracking, 742
- 路径, path, 396
- 轨道, orbit, 310
- 转置, transpose, 252
- 辛形式, symplectic form, 673
- 边界, boundary, 316
- 边际覆盖, marginal coverage, 554
- 运行交集性质, running intersection property, 405
- 近似最优解, approximately optimal solution, 52
- 近共线, nearly collinear, 243
- 连续, continuous, 85
- 连通, connected, 398
- 迭代法, iterative method, 267
- 迹, trace, 254
- 迹类算子, trace-class operator, 237
- 适当, proper, 550
- 选择性预测, selective prediction, 775
- 逐元素乘积, Hadamard product, 253
- 递推, recurrence, 16
- 逻辑后承, logical consequence, 22
- 道德化, moralization, 403
- 道德图, moral graph, 403
- 遗憾匹配, regret matching, 833
- 邻域, neighborhood, 392
- 邻接矩阵, adjacency matrix, 394
- 邻近算子, proximal operator, 151
- 部分和, partial sum, 79
- 部分识别, partial identification, 642
- 链式法则, chain rule, 91
- 锐度, sharpness, 551
- 锐界, sharp bounds, 643
- 错误发现率, false discovery rate, 571
- 长度最短测地线, length-minimizing geodesic, 334
- 闭链, cycle, 316
- 闭集, closed set, 70
- 随机化检验函数, randomized test function, 567
- 随机变量, random variable, 446
- 随机向量, random vector, 447
- 随机干预, stochastic intervention, 627
- 随机序列, random sequence, 480
- 随机微分方程, stochastic differential equation, 702
- 随机游走, random walk, 521
- 随机缺失, missing at random, 538
- 随机过程, stochastic process, 506
- 随机逼近, stochastic approximation, 688
- 隐式超梯度, implicit hypergradient, 188
- 集合, set, 4
- 集合值映射, correspondence, 811
- 集合族, set family, 30
- 零可控性, null controllability, 725
- 零和博弈, zero-sum game, 796
- 零测集, null set, 74
- 零空间, null space, 259
- 零阶保持, zero-order hold, 676
- 非周期的, aperiodic, 522
- 非随机缺失, missing not at random, 538
- 鞅, martingale, 512
- 鞅差, martingale difference, 512
- 鞍点, saddle point, 98
- 预条件, preconditioning, 148, 267
- 预测集合, prediction set, 560
- 频率响应, frequency response, 375
- 风险, risk, 534
- 风险价值, value at risk, 759
- 驻点, stationary point, 132
- 骨架, skeleton, 403, 656
- 高斯分布, Gaussian distribution, 455
- 高斯过程, Gaussian process, 533
- 黏性解, viscosity solution, 786
- Banach 空间, Banach space, 194
- Bayes 决策规则, Bayes decision rule, 773
- Bayes 因子, Bayes factor, 572
- Bayes 行动, Bayes action, 773
- Bernoulli 分布, Bernoulli distribution, 454
- Beta 分布, Beta distribution, 456
- Betti 数, Betti number, 316
- Bootstrap, 562
- Borel σ 代数, Borel sigma-algebra, 73
- Cayley–Hamilton 定理, Cayley–Hamilton theorem, 271
- Čech 复形, Čech complex, 314
- Chapman–Kolmogorov 关系, Chapman–Kolmogorov relation, 511
- Cholesky 分解, Cholesky decomposition, 264
- Clarke 广义梯度, Clarke generalized gradient, 102
- Dirichlet 分布, Dirichlet distribution, 456
- Dirichlet 能量, Dirichlet energy, 341
- Dirichlet 过程, Dirichlet process, 476
- DS 打散, DS shattering, 43
- d-分离, d-separated, 397

- Fenchel-Young 不等式, Fenchel-Young inequality, 163
 Fisher 信息, Fisher information, 557
 Fisher 信息矩阵, Fisher information matrix, 558
 Fisher 度量, Fisher metric, 616
 Fokker-Planck 方程, Fokker-Planck equation, 708
 Fréchet 导数, Fréchet derivative, 229, 300
- Gamma 分布, Gamma distribution, 455
 Gauss-Newton 法, Gauss-Newton method, 145
 Gram 矩阵, Gram matrix, 250, 304
- Hamilton-Jacobi-Bellman 方程, Hamilton-Jacobi-Bellman equation, 783
 Harris 常返性, Harris recurrence, 525
 Hellinger 距离, Hellinger distance, 588
 Hessian 矩阵, Hessian matrix, 96
 Hilbert 空间, Hilbert space, 194
- Itô 等距, Itô isometry, 698
- Jacobian 矩阵, Jacobian matrix, 91
 Jensen 不等式, Jensen's inequality, 135
- Karush-Kuhn-Tucker 条件, Karush-Kuhn-Tucker conditions, 159
 KL 散度, Kullback-Leibler divergence, 550
 Kronecker 积, Kronecker product, 254
- Laplace-Beltrami 算子, Laplace-Beltrami operator, 343
 Levi-Civita 联络, Levi-Civita connection, 328
 Lie 导数, Lie derivative, 747
 Lipschitz 连续, Lipschitz continuous, 86
 Luenberger 观测器, Luenberger observer, 737
 L 光滑, L -smooth, 139
 Lyapunov 函数, Lyapunov function, 680
- Markov 决策过程, Markov decision process, 756
 Markov 等价, Markov equivalent, 656
 Markov 等价类, Markov equivalence class, 656
 Markov 链, Markov chain, 510
 Minkowski 不等式, Minkowski inequality, 193
 Möbius 反演, Möbius inversion, 34
 Moore-Penrose 伪逆, Moore-Penrose pseudoinverse, 262
 M 估计, M -estimation, 542
- Nash 协商解, Nash bargaining solution, 820
- Nash 均衡, Nash equilibrium, 809
 Natarajan 打散, Natarajan shattering, 42
 Nesterov 加速梯度, Nesterov accelerated gradient, 143
 NP 困难, NP-hard, 65
 NP 完全, NP-complete, 65
- ODE 方法, ODE method, 690
- Paley-Wiener 带限空间, Paley-Wiener bandlimited space, 385
 Pareto 最优, Pareto optimal, 182, 803
 Parseval 关系, Parseval relation, 359
 Poisson 分布, Poisson distribution, 454
 Poisson 方程, Poisson equation, 691
 Polyak-Łojasiewicz 条件, PL condition, 141
 p 值, p -value, 567
- q 分位数, quantile, 448
- Rademacher 复杂度, Rademacher complexity, 488
 Radon-Nikodym 导数, Radon-Nikodym derivative, 450
 Rayleigh 商, Rayleigh quotient, 282
 Rényi 散度, Rényi divergence, 589
 Riemann Hessian, 337
 Riemann 度量, Riemannian metric, 322
 Riemann 曲率, Riemann curvature, 335
 Riemann 梯度, Riemannian gradient, 337
- Schatten p 范数, Schatten p -norm, 281
 Schur 补, Schur complement, 264
 Shapley 值, Shapley value, 805
 Sylvester 方程, Sylvester equation, 258
- 假设检验, hypothesis testing, 567
 偏导数, partial derivative, 89
 偏序关系, partial order, 6
 停时, stopping time, 510
 傅里叶系数, Fourier coefficient, 360
 充分统计量, sufficient statistic, 541
 入度, in-degree, 392
 全局最优解, global minimizer, 132
 全局最小点, global minimizer, 11
 全方差公式, law of total variance, 464
 全期望公式, law of total expectation, 464
 全称量词, universal quantifier, 18
 共同下降方向, common descent direction, 183
 共同原因, common cause, 651

- 共轭对称, conjugate symmetry, 359
- 共轭转置, conjugate transpose, 252, 359
- 关联矩阵, incidence matrix, 394
- 内积, inner product, 192
- 内积空间, inner-product space, 192
- 内部遗憾, internal regret, 828
- 再生核, reproducing kernel, 218
- 再生核 Hilbert 空间, reproducing kernel Hilbert space, 199
- VC 维, Vapnik–Chervonenkis dimension, 37
- 几乎处处, almost everywhere, 74
- 几何遍历性, geometric ergodicity, 525
- 凸共轭, convex conjugate, 163
- 凸函数, convex function, 135
- 凸松弛, convex relaxation, 172
- 凸集, convex set, 135
- 出度, out-degree, 392
- 函数, function, 7
- 分位数回归, quantile regression, 549
- 分块坐标法, block coordinate method, 177
- 分布, distribution, 447
- 分布鲁棒优化, distributionally robust optimization, 763
- 分离原则, separation principle, 791
- 分离原理, separation principle, 737
- 分隔, separate, 402
- 切空间, tangent space, 318
- 列空间, column space, 259
- 创新协方差, innovation covariance, 715
- 判定问题, decision problem, 61
- 到达概率, reach probability, 802
- 前向误差, forward error, 289
- 前馈, feedforward, 743
- 剩余类, residue class, 365
- 加权平均, weighted average, 15
- 加权重, weighted degree, 420
- 加权最小二乘, weighted least squares, 261
- 动量法, momentum, 142
- 包络定理, envelope theorem, 101
- 匹配, matching, 419
- 区分能力, discrimination, 551
- 半可判定的, semidecidable, 62
- 半正定锥, positive semidefinite cone, 162
- 半环, semiring, 436
- 协变导数, covariant derivative, 327
- 单射, injective, 8
- 单纯形, simplex, 313
- 单纯顶点, simplicial vertex, 409
- 单调性, monotonicity, 54, 646
- 占用度量, occupancy measure, 780
- 卡方分布, chi-square distribution, 457
- 卷积, convolution, 255
- 卷积核, convolution kernel, 371
- 压缩映射, contraction mapping, 81
- 原像, preimage, 7
- 原始关系图, primal graph, 393
- 原始-对偶间隙, primal-dual gap, 184
- 双层优化, bilevel optimization, 186
- 双重中心化, double centering, 305
- 反事实, counterfactual, 633
- 反事实价值, counterfactual value, 831
- 反事实公平, counterfactual fairness, 637
- 反事实遗憾最小化, counterfactual regret minimization, 832
- 反馈, feedback, 723
- 可交换, exchangeable, 472
- 可信区间, credible interval, 560
- 可判定的, decidable, 62
- 可加性, additivity, 805
- 可微, differentiable, 89
- 可控 Gram 矩阵, controllability Gramian, 726
- 可枚举的, computably enumerable, 62
- 可测函数, measurable function, 104
- 可测空间, measurable space, 72
- 可测集合, measurable set, 72
- 可满足, satisfiable, 22
- 可计算函数, computable function, 62
- 可识别, identifiable, 638
- 可识别的, identifiable, 536
- 可转移效用合作博弈, transferable-utility cooperative game, 804
- 可预测二次变差, predictable quadratic variation, 514
- 可预测过程, predictable process, 510
- 合取范式, conjunctive normal form, 21
- 同构, isomorphic, 395
- 同调空间, homology space, 316
- 后代, descendant, 397
- 后向稳定, backward stability, 290
- 后向误差, backward error, 289
- 后门准则, back-door criterion, 654
- 后门路径, back-door path, 653
- 后验分布, posterior distribution, 545
- 向量化, vectorization, 246
- 向量场, vector field, 327
- 向量空间, vector space, 244

- 周期, period, 522
- 命题, proposition, 17
- 哑索引, dummy index, 14
- 商空间, quotient space, 245
- 回缩, retraction, 338
- 因果 Markov 性, causal Markov condition, 653
- 因果响应, causal response, 625
- 团, clique, 405
- 团树, junction tree, 411
- 图信号, graph signal, 429
- 图傅里叶变换, graph Fourier transform, 429
- 坐标, coordinates, 245
- 坐标图, chart, 308
- 坐标过渡, coordinate transition, 308
- 基, basis, 245
- 基带, baseband, 385
- 填充边, fill-in edge, 407
- 增广路径, augmenting path, 419
- 复共轭, complex conjugate, 352
- 复制动态, replicator dynamics, 826
- 复合, composition, 8
- 复合泊松过程, compound Poisson process, 528
- 外部遗憾, external regret, 828
- 多元高斯随机向量, multivariate Gaussian random vector, 460
- 多方信用分配, multi-party credit allocation, 804
- 多重集合, multiset, 434
- 多项分布, multinomial distribution, 454
- 多项式插值, polynomial interpolation, 364
- 多项式时间多对一归约, polynomial-time many-one reduction, 65
- 奇异值, singular value, 278
- 奇异值分解, singular value decomposition, 278
- Vietoris–Rips 复形, Vietoris–Rips complex, 314
- Ville 不等式, Ville's inequality, 517
- 存在量词, existential quantifier, 18
- 完全信息价值, expected value of perfect information, 788
- 完全回忆, perfect recall, 799
- 完全图, complete graph, 405
- 完全随机缺失, missing completely at random, 538
- 完备, complete, 78
- 完备性, completeness, 76
- 完备正交系, complete orthonormal system, 202
- 完美有向图, perfect directed acyclic graph, 403
- 完美消元序, perfect elimination ordering, 409
- 容斥原理, inclusion–exclusion principle, 33
- 对偶函数, dual function, 161
- 对偶范数, dual norm, 248
- 对数损失, log loss, 582
- 对称归一化拉普拉斯, symmetric normalized Laplacian, 421
- 对称性, symmetry, 805
- 对角化, diagonalization, 272
- 导数, derivative, 89
- 局部 Lipschitz 函数, locally Lipschitz function, 86
- 局部最优解, local minimizer, 132
- 嵌套动态风险, nested dynamic risk, 766
- 布尔公式, Boolean formula, 20
- 布尔可满足性问题, Boolean satisfiability problem, 50
- 布朗运动, Brownian motion, 530
- 常返状态, recurrent state, 523
- 幂集, power set, 5
- 干预, intervention, 626
- 平均处理效应, average treatment effect, 629
- 平移不变性, translation invariance, 370
- 平稳分布, stationary distribution, 511
- 平稳过程, stationary process, 520
- 平行四边形恒等式, parallelogram identity, 193
- 平行移动, parallel transport, 329
- 广义特征值问题, generalized eigenvalue problem, 284
- 广度优先搜索, breadth-first search, 400
- 序列紧致性, sequential compactness, 87
- 度, degree, 392
- 度量, metric, 70
- 度量空间, metric space, 70
- 开环控制, open-loop control, 724
- 开覆盖, open cover, 87
- 开集, open set, 70
- 张成空间, span, 244
- 张量, tensor, 246
- 张量缩并, tensor contraction, 253
- 弦, chord, 409
- 弦化, chordal completion, 409
- 弦图, chordal graph, 409
- 弯曲点带, curved point band, 308
- ρ 弱凸, ρ -weakly convex, 154
- 弱对偶, weak duality, 161
- 弱导数, weak derivative, 197
- 弱连通, weakly connected, 399
- 强制的, coercive, 134
- 强解, strong solution, 703
- 强连通, strongly connected, 399
- 归一化割, normalized cut, 425
- 归一化指数映射, softmax, 92

- 形状重整, reshape, 246
- 影响函数, influence function, 543
- 循环卷积, circular convolution, 373
- 微分熵, differential entropy, 582
- 忠实性, faithfulness, 655
- 快速傅里叶变换, fast Fourier transform, 379

- 总变差距离, total variation distance, 524, 587
- 战略式博弈, strategic-form game, 795
- 截断 SVD, truncated SVD, 284
- 截断分解, truncated factorization, 650
- 截面曲率, sectional curvature, 335
- 打散, shatter, 37
- 扩展式博弈, extensive-form game, 798
- 投影, projection, 155
- 抗混叠滤波, anti-aliasing filtering, 388
- 抽样制度, sampling regime, 536
- 抽象单纯复形, abstract simplicial complex, 314
- 拉格朗日函数, Lagrangian, 159
- 拓扑, topology, 313
- 拟牛顿法, quasi-Newton method, 146
- 指数分布, exponential distribution, 455
- 指数族, exponential family, 458
- 指数映射, exponential map, 332
- 探索, exploration, 790
- 控制 Lyapunov 函数, control Lyapunov function, 732
- 搜索问题, search problem, 61
- 支持重叠, overlap, 640
- 支撑超平面, supporting hyperplane, 162
- 支配, dominate, 182
- 收敛, converge, 75
- 散度定理, divergence theorem, 117
- 数值秩, numerical rank, 287
- 数列, sequence, 75
- 数理统计, mathematical statistics, 534
- 整数间隙, integrality gap, 174
- 方向导数, directional derivative, 89, 229
- 族错误率, family-wise error rate, 570
- 无下界, unbounded below, 132
- 无向图, undirected graph, 392
- 无屏蔽碰撞结构, unshielded collider, 656
- 无环, acyclic, 648
- 无穷级数, infinite series, 79
- 时间一致性, time consistency, 766
- 时间齐次的, time-homogeneous, 510
- 替代梯度, surrogate gradient, 103

- 最优传输, optimal transport, 592
- 最佳响应, best response, 807
- 最大公因式, greatest common divisor, 365
- 最大均值差异, maximum mean discrepancy, 590
- 最大熵原理, maximum entropy principle, 606
- 最小二乘, least squares, 260
- 最小描述长度, minimum description length, 574
- 最小生成树, minimum spanning tree, 418
- 有向图, directed graph, 392
- 有向无环图, directed acyclic graph, 396
- 有向环, directed cycle, 396
- 有向路径, directed path, 396
- 有效定义域, effective domain, 133
- 有效性, efficiency, 805
- 有效秩, effective rank, 288
- 有效维度, effective dimension, 237
- σ 有限, sigma-finite, 111
- 有限子覆盖, finite subcover, 87
- 期望 Rademacher 复杂度, expected Rademacher complexity, 488
- 期望样本信息价值, expected value of sample information, 788
- 本质上确界, essential supremum, 121
- 机会约束, chance constraint, 763
- 权重, weight, 393
- 条件互信息, conditional mutual information, 586
- 条件交换性, conditional exchangeability, 639
- 条件平均处理效应, conditional average treatment effect, 630
- 条件数, condition number, 290
- 条件期望, conditional expectation, 462
- 条件熵, conditional entropy, 580
- 条件风险, conditional risk, 773
- 条件风险价值, conditional value at risk, 760
- 条件风险映射, conditional risk mapping, 765
- 极分解, polar decomposition, 280
- 极小极大鞍点, minimax saddle point, 184
- ω 极限集, ω -limit set, 679
- 查询树, query tree, 214
- 柯西数列, Cauchy sequence, 77
- 标准 Borel 空间, standard Borel space, 467
- 树, tree, 399
- 树分解, tree decomposition, 405
- 树宽, treewidth, 406
- 校准, calibration, 551
- 核心, core, 819
- 核范数, nuclear norm, 281
- 梯度, gradient, 90

- 概率有界, bounded in probability, 500
- 概率核, probability kernel, 466
- 概率测度的弱收敛, weak convergence of probability measures, 502
- 概率空间, probability space, 446
- 模型, model, 20
- 次梯度, subgradient, 150
- 次模, submodular, 422
- 次模函数, submodular function, 54
- 次高斯变量, sub-Gaussian random variable, 481
- 正 Harris 常返性, positive Harris recurrence, 525
- 正交, orthogonal, 247
- 正交投影, orthogonal projection, 250
- 正值性, positivity, 640
- 正则条件分布, regular conditional distribution, 466
- 正向不变集, positively invariant set, 679
- 正定核, positive definite kernel, 219
- 正权支撑, positive-weight support, 393
- 正规方程, normal equations, 260
- 残差, residual, 293
- 比率割, RatioCut, 424
- 泊松过程, Poisson process, 527
- 注意力, attention, 255
- 活跃, active, 397
- 流, flow, 416
- 流形, manifold, 307
- 测地凸性, geodesic convexity, 338
- 测地线, geodesic, 331
- 测地距离, geodesic distance, 324
- 测度, measure, 72
- 测度空间, measure space, 72
- 消元, elimination, 407
- 深度优先搜索, depth-first search, 400
- 混叠, aliasing, 384
- 混合策略, mixed strategy, 797
- 混合范数, mixed norm, 257
- 混合速度, mixing rate, 526
- 渐近稳定, asymptotically stable, 679
- 游走, walk, 396
- 满射, surjective function, 8
- 满足, satisfy, 20
- 滤波分布, filtering distribution, 715
- 滤过, filtration, 510
- 演化稳定策略, evolutionarily stable strategy, 826
- 潜在点, latent point, 309
- 潜在结果, potential outcome, 626
- Wolfe 曲率条件, Wolfe curvature condition, 147
- Woodbury 恒等式, Woodbury identity, 265