MACHINE LEARNING NOTES

# 机器学习笔记

## 卷二：基础、理论和可信性

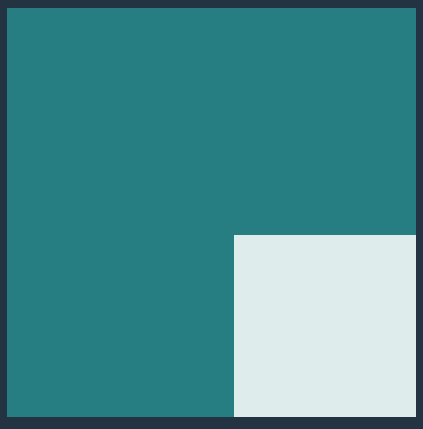

施晓罡

2026 年・第一版

MACHINE LEARNING NOTES

# 机器学习笔记

## 卷二：基础、理论和可信性

施晓罡

2026 年・第一版

**机器学习笔记**

MACHINE LEARNING NOTES

作者：施晓罡

版本：第一版

年份：2026

Copyright © 2026 施晓罡

Licensed under the Creative Commons Attribution-NonCommercial-NoDerivatives 4.0 International License (the ”License”);

You may not use this file except in compliance with the License.

You may obtain a copy of the License at

https://creativecommons.org/licenses/by-nc-nd/4.0/

Unless required by applicable law or agreed to in writing, software distributed under the License is distributed on an ”AS IS” BASIS, WITHOUT WARRANTIES OR CONDITIONS OF ANY KIND, either express or implied. See the License for the specific language governing permissions and limitations under the License.

# 前言

## 本书目标

机器学习把数据、模型和计算连接起来，但理解一种方法，不能只记住模型名称或训练步骤。还需要知道模型能够表示什么规律，学习结论依赖哪些数据与假设，什么证据足以支持评价，以及方法进入具体应用和运行系统后会受到哪些约束。本书沿着这些联系组织内容，希望读者不仅会使用算法，也能解释一个结果为何成立、何时可信，以及怎样把它放入完整的技术过程。

本书面向已经具备基本微积分、线性代数、概率统计和编程基础，希望系统理解机器学习的读者。正文会在需要时回顾具体工具，但不以这些基础课程的完整讲解为目标。阅读后，读者应能从任务和证据出发比较模型与学习方式，并把理论条件、实验评价、应用要求和系统实现放在同一条推理链上考察。

## 本书内容

全书分为六卷。第一卷“数学准备”建立分析、代数、概率、离散结构与动态决策的共同语言。第二卷“基础、理论和可信性”说明学习如何发生、学习保证依赖哪些条件，以及可靠性、鲁棒性、公平性和隐私等可信要求应由什么证据支持。第三卷“模型”考察经典模型、神经网络模型和概率图模型的结构、推断与学习。第四卷“范式”转向经验和知识的获得方式，讨论交互反馈、有限标注以及任务变化下如何学习、复用和迁移知识。前四卷提供数学工具、分析依据和方法选择，后两卷把这些选择放入实际约束。第五卷“应用”围绕自然语言处理、图像处理、推荐与搜索，说明任务目标、数据形态、模型和评价方式如何相互制约。第六卷“系统”连接数据准备、训练计算、部署服务与运行维护，考察方法如何成为可持续运行的机器学习系统。这样的次序并不表示建模、应用和系统彼此割裂：应用需求决定评价口径，系统条件限制可用方法，而运行中的证据又会促使模型和学习过程重新调整。

## 参考资料

下面按内容列出可与本书配合阅读的教材。每本书的侧重点不同，读者可以根据正在阅读的卷和需要补充的问题选择查阅，不必按列表顺序通读。

### 综合与基础

- Mitchell 的 *Machine Learning* 从概念学习、归纳偏置和代表性算法出发，适合查阅机器学习的基本问题和早期统一框架。
- Bishop 的 *Pattern Recognition and Machine Learning* 将概率建模、决策理论、核方法和近似推断联系起来，适合查阅概率视角下的模型与推断方法。
- 周志华的《机器学习》覆盖常用模型、学习理论和实践问题，适合按任务比较方法的基本假设与用途。
- 李航的《统计学习方法（第 2 版）》以统计机器学习为定位，适合按模型查阅定义、算法和数学推导。
- Deisenroth、Faisal 和 Ong 的 *Mathematics for Machine Learning* 适合补充线性代数、解析几何、矩阵微积分、概率与优化等数学工具。

### 统计学习与学习理论

- Hastie、Tibshirani 和 Friedman 的 *The Elements of Statistical Learning* 适合查阅回归、分类、正则化、模型选择和统计学习方法。
- Shalev-Shwartz 和 Ben-David 的 *Understanding Machine Learning: From Theory to Algorithms* 适合查阅 PAC 框架、复杂度、泛化界与优化基础。
- Mohri、Rostamizadeh 和 Talwalkar 的 *Foundations of Machine Learning* 适合查阅学习界、核方法、在线学习及其理论保证。
- James、Witten、Hastie 和 Tibshirani 的 *An Introduction to Statistical Learning* 适合结合 R 实例理解回归、分类、重采样、正则化、树模型和无监督学习。

### 概率模型与图模型

- Murphy 的 *Machine Learning: A Probabilistic Perspective* 以概率视角组织监督学习、无监督学习、潜变量模型和图模型，适合查阅模型间的联系。

- Murphy 的 *Probabilistic Machine Learning: An Introduction* 适合查阅现代概率机器学习的统一记号、计算方法和模型实例。
- Murphy 的 *Probabilistic Machine Learning: Advanced Topics* 适合查阅深度生成模型、状态空间模型、贝叶斯优化和相关近似推断方法。
- Koller 和 Friedman 的 *Probabilistic Graphical Models: Principles and Techniques* 适合系统查阅图模型的表示、精确与近似推断以及参数和结构学习。
- Rasmussen 和 Williams 的 *Gaussian Processes for Machine Learning* 适合深入理解高斯过程、核函数、贝叶斯预测和超参数学习。

### 神经网络与深度学习

- Goodfellow、Bengio 和 Courville 的 *Deep Learning* 适合查阅神经网络表示、优化、正则化和深度生成模型。
- Bishop 和 Bishop 的 *Deep Learning: Foundations and Concepts* 从概率基础连接常用架构与训练方法，适合查阅相应概念和推导。
- 邱锡鹏的《神经网络与深度学习》适合查阅前馈、卷积、循环、注意力网络及其训练方法。
- Zhang、Lipton、李沐和 Smola 的 *Dive into Deep Learning* 适合结合可运行代码理解神经网络的实现、训练与调参过程。
- Géron 的 *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow* 适合查阅从数据准备、模型训练到评估和部署的实践流程。

### 强化学习

- Sutton 和 Barto 的 *Reinforcement Learning: An Introduction* 适合查阅马尔可夫决策过程、价值方法、策略方法与函数逼近。
- Szepesvári 的 *Algorithms for Reinforcement Learning* 适合查阅动态规划、Monte Carlo、时序差分和函数逼近算法的数学形式与分析。

### 应用与系统

- Manning、Raghavan 和 Schütze 的 *Introduction to Information Retrieval* 适合查阅文本表示、索引、检索模型和评价方法。
- Huyen 的 *Designing Machine Learning Systems* 从数据、训练、部署与监控讨论机器学习系统设计，适合查阅模型进入生产环境后的工程约束。

- Jurafsky 和 Martin 的 *Speech and Language Processing* 适合查阅自然语言与语音处理中的语言模型、序列标注、句法分析和语音识别。
- Szeliski 的 *Computer Vision: Algorithms and Applications* 适合查阅成像、特征、几何、识别与图像合成方法。
- Aggarwal 的 *Recommender Systems: The Textbook* 适合查阅协同过滤、基于内容的推荐、矩阵分解和推荐评价。
- Kleppmann 和 Riccomini 的 *Designing Data-Intensive Applications* 适合查阅存储、复制、分区、事务以及流式与批量处理的系统取舍。

上述教材的完整出版信息列于卷末参考文献。

# 数学符号

下表汇总全书反复使用的记号。各章若赋予符号更具体的含义，会在首次使用时另行说明。

**对象与线性代数**

| 对象 | 常用记号 | 含义 |
|---|---|---|
| 数集 | $\mathbb{N}$, $\mathbb{Z}$, $\mathbb{R}$, $\mathbb{R}_+$ | 自然数集、整数集、实数集和非负实数集 |
| 集合与关系 | $x \in A$, $A \subseteq B$, $A \cup B$, $A \cap B$, $\lvert A \rvert$ | 元素属于集合、子集、并集、交集和有限集合的基数 |
| 标量 | $a$, $x$, $\lambda \in \mathbb{R}$ | 单个数值；小写斜体字母通常表示标量 |
| 向量 | $\boldsymbol{x}$, $\boldsymbol{w} \in \mathbb{R}^d$ | $d$ 维向量；加粗小写字母表示向量 |
| 矩阵 | $\boldsymbol{A} \in \mathbb{R}^{m \times n}$, $\boldsymbol{A}_{i,j}$ | $m$ 行 $n$ 列矩阵及其第 $i$ 行、第 $j$ 列元素 |
| 数据与样本 | $\mathcal{D} = \{(\boldsymbol{x}_i, y_i)\}_{i=1}^n$ | 含 $n$ 个输入标签对的数据集；下标 $i$ 表示样本索引 |
| 切片与迭代 | $\boldsymbol{A}_{i,:}$, $\boldsymbol{A}_{:,j}$, $\boldsymbol{w}^{(t)}$ | 矩阵的第 $i$ 行、第 $j$ 列，以及第 $t$ 次迭代的向量 |
| Kronecker delta | $\delta_{i,j}$ | 当 $i = j$ 时取 1，否则取 0 |
| 矩阵变换 | $\boldsymbol{A}^\top$, $\boldsymbol{A}^{-1}$, $\boldsymbol{A}^\dagger$, $\boldsymbol{I}_d$, $\operatorname{tr}(\boldsymbol{A})$ | 转置、逆、伪逆、$d$ 阶单位矩阵和矩阵的迹 |
| 代数运算 | $\langle \boldsymbol{x}, \boldsymbol{y} \rangle$, $\boldsymbol{x}^\top \boldsymbol{A} \boldsymbol{x}$, $\sum_i a_i$, $\prod_i a_i$ | 内积、二次型、求和与连乘 |
| 函数与模型 | $f : \mathcal{X} \to \mathcal{Y}$, $h_{\boldsymbol{w}}(\boldsymbol{x})$ | 从输入空间到输出空间的函数，以及参数为 $\boldsymbol{w}$ 的模型 |
| 范数与距离 | $\lVert \boldsymbol{x} \rVert_p$, $d(\boldsymbol{x}, \boldsymbol{y})$ | $p$ 范数与两对象之间的距离；具体定义由上下文给出 |

**微积分与优化**

| 对象 | 常用记号 | 含义 |
|---|---|---|
| 导数与梯度 | $\dfrac{\mathrm{d}f}{\mathrm{d}x}$, $\nabla_{\boldsymbol{w}} L(\boldsymbol{w})$ | 一元导数，以及标量值函数对参数向量的梯度 |
| Jacobian 与 Hessian | $\nabla_{\boldsymbol{x}} \boldsymbol{f}$, $\nabla_{\boldsymbol{x}}^2 f$ | 向量值函数的一阶偏导矩阵，以及标量值函数的二阶偏导矩阵 |
| 渐近阶 | $f(n) = \mathcal{O}(g(n))$ | 函数增长率的渐近上界 |
| 最优化 | $\min_{\boldsymbol{w}} L(\boldsymbol{w})$, $\boldsymbol{w}^* \in \arg\min_{\boldsymbol{w}} L(\boldsymbol{w})$ | 最小目标值与取得最小值的参数；最大化使用 max 和 arg max |

**概率与信息论**

| 对象 | 常用记号 | 含义 |
| --- | --- | --- |
| 随机变量与实现 | $X,\ \boldsymbol{X},\ x,\ \boldsymbol{x},\ p_X(x)$ | 随机标量、随机向量及其实现值；$p_X$ 表示概率质量或密度函数 |
| 联合与条件概率 | $p(x,y),\ p(x \mid y)$ | 随机变量实现值的联合概率与条件概率 |
| 边缘概率 | $p(x)=\sum_y p(x,y),\ p(x)=\int p(x,y)\,\mathrm{d}y$ | 分别对离散变量求和或对连续变量积分得到的边缘概率 |
| 独立性与抽样 | $X \perp Y,\ X \perp Y \mid Z,\ X_i \overset{\text{i.i.d.}}{\sim} p$ | 独立、给定 $Z$ 条件独立，以及独立同分布抽样 |
| 矩与相关性 | $\mathbb{E}[X],\ \mathrm{Var}(X),\ \mathrm{Cov}(X,Y)$ | 期望、方差和协方差 |
| 常用分布 | $\mathrm{Bernoulli}(p),\ \mathrm{Cat}(\boldsymbol{\pi}),\ \mathcal{N}(\boldsymbol{\mu},\boldsymbol{\Sigma})$ | 伯努利分布、类别分布和多元高斯分布 |
| 事件指示函数 | $\mathbb{I}\{A\}$ | 事件 $A$ 成立时取 1，否则取 0 |
| 信息量 | $H(p),\ H(p,q),\ \mathrm{KL}(p\|\|q)$ | 熵、交叉熵和分布 $p$ 相对于 $q$ 的 KL 散度 |
| 概率正比关系 | $p(\boldsymbol{x}) \propto q(\boldsymbol{x})$ | 忽略归一化常数时的概率正比关系 |

# 目录


第一部分 机器学习基础 1

第 1 章 引言 3

1.1 什么是机器学习 3

1.2 例子：垃圾邮件分类 5

1.3 任务 12

1.4 经验 19

1.5 性能度量 22

1.6 本章小结 24

第 2 章 模型简介 25

2.1 什么是模型 25

2.2 参数化方式与表示规模 27

2.3 变量的概率语义 30

2.4 变量的关系形式 35

2.5 输出的形式与含义 39

2.6 损失与学习准则 40

2.7 模型维度的交叉与组合 47

2.8 本章小结 51

第 3 章 范式简介 52

3.1 监督学习 53

3.2 无监督学习 54

3.3 强化学习 56

3.4 知识的获取 59

3.5 知识的演进与迁移 68

3.6 其他范式 76

3.7 范式的组合 79
3.8 本章小结 80

第二部分 机器学习理论 83

第 4 章 机器学习理论基础 85
4.1 学习问题 85
4.2 PAC 学习 92
4.3 学习的限制 97
4.4 风险来源与模型选择 102
4.5 研究内容 108
4.6 本章小结 115

第 5 章 二分类学习的可学习性 116
5.1 可实现的有限假设空间 116
5.2 不可知的有限假设空间 118
5.3 无限假设空间 122
5.4 估计期望风险 127
5.5 样本压缩 132
5.6 集成学习 136
5.7 可计算 PAC 学习 142
5.8 本章小结 147

第 6 章 多分类学习的可学习性 148
6.1 从二分类到多分类 148
6.2 有限标签空间及 Natarajan 维的边界 150
6.3 图维、DS 维与一般标签空间 155
6.4 可计算 PAC 学习 164
6.5 本章小结 168

第 7 章 一般学习的可学习性 169
7.1 一般学习问题 169
7.2 一致收敛 171
7.3 算法稳定性与可学习性 175
7.4 凸学习问题 204
7.5 非凸学习问题 213
7.6 本章小结 219

第 8 章 深度学习的可学习性 221
8.1 神经网络的学习问题 221
8.2 基于参数大小的可学习性 226
8.3 基于参数梯度初始值的可学习性 232
8.4 基于参数梯度更新的可学习性 241
8.5 基于参数分布的可学习性 251
8.6 理论的比较与使用 259
8.7 本章小结 260

第 9 章 迁移学习的可学习性 262
9.1 迁移学习的学习问题 262
9.2 领域自适应的可学习性 268
9.3 领域泛化的可学习性 281
9.4 本章小结 288

第三部分 机器学习可信性 289

第 10 章 可信机器学习基础 291
10.1 技术可信性的范围与三个层次 292
10.2 系统属性与规范要求 296
10.3 证据能支持什么结论 298
10.4 失效、处置与生命周期条件 301
10.5 例子：邮件隔离的完整保证记录 302
10.6 研究内容 304
10.7 本章小结 312

第 11 章 可靠性 314
11.1 不确定性的来源与估计 315
11.2 可靠性的检验 319
11.3 可靠性的保证 325
11.4 本章小结 331

第 12 章 鲁棒性 332
12.1 模型的鲁棒性 332
12.2 鲁棒性的检验 334
12.3 鲁棒性的增强 338

12.4 本章小结 344

第 13 章 公平性 345

13.1 模型的公平性 345

13.2 公平性的判定 348

13.3 公平性的干预 356

13.4 本章小结 362

第 14 章 目标对齐与行为约束 363

14.1 目标对齐与行为约束的基本概念 363

14.2 行为的评估与监督 367

14.3 行为泛化与约束保持的条件 373

14.4 行为干预 377

14.5 本章小结 384

第 15 章 可解释性 386

15.1 模型的可解释性 386

15.2 整体行为的解释 388

15.3 单次行为的解释 392

15.4 解释的质量 400

15.5 行动补救 403

15.6 本章小结 407

第 16 章 隐私保护 409

16.1 隐私保护的基本概念 409

16.2 隐私保护的验证 412

16.3 隐私保护的实现 418

16.4 数据撤回与模型消除 425

16.5 本章小结 432

第 17 章 对抗安全 433

17.1 对抗安全的基本概念 433

17.2 脆弱性的评估 437

17.3 攻击防御与损害控制 448

17.4 本章小结 455

参考文献 . . . . . 456

索引 . . . . . 476

第一部分

# 机器学习基础

Machine Learning Basics

# 阅读指引

一批历史邮件可以提供类别答案，却不会自动给出判断新邮件的规则。我们还要决定读取哪些信息、允许哪些计算关系、怎样根据答案选择参数，以及如何用未参与选择的邮件检验结果。本部分从这一过程建立任务、经验、模型、学习和评价的含义，为后续各卷提供共同的讨论对象。

《引言》沿垃圾邮件分类的准备、训练、预测和评价展开：每一步都说明使用什么信息、得到什么结果，并区分训练误差与新邮件上的错误。《模型简介》继续固定任务，比较权重、条件规则和实例等表示，再从规模、概率、关系、输出及学习准则解释模型的差别。《范式简介》改变经验条件，讨论标签不足、行动只有后果、新旧任务和分散数据出现时，学习怎样组织。

读完三章，我们应能说明一个系统要预测或执行什么、模型保留了哪些关系、训练依据来自哪里，以及现有评价能够支持多大范围的结论。理论部分随后固定抽样方式、损失和比较基准，研究有限经验何时足以支持学习保证。可信性部分再检查保证之外的使用条件：预测是否可靠、变化和不同人群怎样影响结果、信息与操作权限怎样受限，以及失效以后如何发现和处置。

第 1 章

# 引言

## 1.1 什么是机器学习

### 1.1.1 什么是学习

孩子见过几只猫和狗后，可能认出另一只没有见过的猫；学生练习解方程，则希望把解题方法用于新的方程。两个例子都有一个共同点：过去的经历改变了以后处理问题的方式。驾驶员根据路况和操作反馈调整驾驶行为，也属于这样的变化。我们用“学习”描述这些现象时，关注的是经验留下了什么可以保持的能力，而不只是当时答对了多少次。疲劳或兴奋也会改变一次操作的结果，但这种短暂波动本身不足以说明发生了学习。

把这一问题交给计算机，就要说明程序如何从有限记录得到处理新输入的规则，以及用什么证据判断规则是否有效。我们将跟随一个垃圾邮件分类器，观察数据如何进入模型、参数如何通过训练改变，以及训练完成后怎样预测和评价。任务、经验和性能度量将在这个过程中获得具体含义。尤其需要区分两个结果：程序在用于训练的邮件上分类正确，以及它能正确处理没有参与训练的邮件。理论部分会在规定数据、损失和比较对象后，研究有限经验能否支持可证明的学习保证。这样的保证仍有适用条件；实际使用中的人群、环境、权限与风险要求，还要在可信性部分逐项考察。

有限观察怎样支持尚未观察到的结论，也是哲学研究经验与知识关系时提出的问题。**演绎**（deduction）要求结论由给定前提保证；**归纳**（induction）则从已经观察到的情形形成更广的判断。D. Hume（休谟）讨论过其中的困难：过去发生的事情，不能仅凭演绎就保证在未来继续发生[1]。训练记录与未来输入之间也存在这一步跨越。要从已见邮件推测新邮件的类别，程序除了利用记录，还必须采用某些假设，规定哪些关系可以延续到没有观察过的情形。

[1] D. Hume, *An Enquiry Concerning Human Understanding*, 1748

研究者还需要选择能够观察的变化。心理学可以考察行为是否改变，也可以研究经验怎样改变知识和表征，也就是组织、理解信息的方式。**条件作用**（conditioning）研究刺激、反应和结果之间形成的联系；例如，得到奖励的行为以后可能更频繁地出现。认知取向还关注记忆、概念和策略的

变化。这些研究对象表明，学习包含的变化比事实记忆更广。De Houwer 等人提出的功能性定义，便以环境规律引起的行为改变来界定学习[2]。

[2] J. De Houwer, D. Barnes-Holmes, A. Moors, *What Is Learning? On the Nature and Merits of a Functional Definition of Learning* In Psychonomic Bulletin & Review, 2013, vol. 20, no. 4, pp. 631–642

### 1.1.2 从学习到机器学习

邮件的写法持续变化，靠人工逐条补充关键词和例外，很难维护一套充分的拦截规则。与此同时，过去收到的邮件及其处理结果已经留下了记录。能否让程序利用这些记录调整判断规则，并用新邮件检验调整的效果？**机器学习**（machine learning, ML）研究的正是这类利用经验改变程序行为的问题。这里沿用学习的基本直觉，不要求程序复制人的心理过程；可利用的经验也可以来自与环境交互得到的反馈。

早期研究从不同对象出发探索这种可能性。McCulloch 和 Pitts 研究理想化神经元构成的网络，Turing 讨论通过教育和经验培养机器，Rosenblatt 的感知机根据分类错误调整连接权重，Samuel 的跳棋程序利用棋局记录和自我对弈改进决策[3,4,5,6]。分类结果与对弈结果提供了不同形式的反馈，分别为按已知答案学习和通过交互学习提供了早期例子。

[3] W. S. McCulloch, W. Pitts, *A Logical Calculus of the Ideas Immanent in Nervous Activity* In The Bulletin of Mathematical Biophysics, 1943, vol. 5, pp. 115–133

[4] A. M. Turing, *Computing Machinery and Intelligence* In Mind, 1950, vol. 59, no. 236, pp. 433–460

[5] F. Rosenblatt, *The Perceptron: A Probabilistic Model for Information Storage and Organization in the Brain* In Psychological Review, 1958, vol. 65, no. 6, pp. 386–408

[6] A. L. Samuel, *Some Studies in Machine Learning Using the Game of Checkers* In IBM Journal of Research and Development, 1959, vol. 3, no. 3, pp. 210–229

程序能够随样本改变，还不足以解释它在新样本上的行为。Vapnik 和 Chervonenkis 等人的研究，把有限样本提供的统计保证与候选规则的复杂度联系起来[7]。训练多层网络还面临计算问题，**误差反向传播**（error backpropagation）为参数调整提供了计算方法[8]。随着数据、计算和模型规模扩大，**表示学习**（representation learning）与**深度学习**（deep learning）进一步研究如何从复杂输入中学习任务所需的表示[9]。统计保证、参数求解和输入表示回答的是不同问题：从哪些规则中选择，怎样完成选择，以及选择时能够利用什么信息。

[7] V. N. Vapnik, A. Y. Chervonenkis, *On the Uniform Convergence of Relative Frequencies of Events to Their Probabilities* In Theory of Probability and Its Applications, 1971, vol. 16, no. 2, pp. 264–280

[8] D. E. Rumelhart, G. E. Hinton, R. J. Williams, *Learning representations by back-propagating errors* In Nature, 1986, vol. 323, no. 6088, pp. 533–536

[9] Y. LeCun, Y. Bengio, G. Hinton, *Deep Learning* In Nature, 2015, vol. 521, pp. 436–444

说明一个学习系统，需要同时借助不同学科的工具。**人工智能**（artificial intelligence）研究智能任务与行动；**概率论**（probability theory）和**统计学**（statistics）帮助描述不确定性并从有限记录估计规律；**优化**（optimization）研究怎样求解参数选择问题。信息论、信号处理和控制分别提供编码与表示、信号变换和反馈分析工具，数据系统承担采集、存储与计算。**数据挖掘**（data mining）也使用分类、聚类和**异常检测**（anomaly detection），侧重在已有数据中发现可用模式。应用领域则规定答案的含义、错误代价和使用限制。这些联系说明，仅给出模型名称还不足以描述机器学习；我们还要交代它利用什么经验、怎样学习、怎样评价。下面先用一个定义固定其中最基本的三项。

### 1.1.3 机器学习的定义

判断经验是否带来了改进，需要把比较说清楚。同一个程序可以执行多项任务，同一次调整也可能降低一种错误而增加另一种错误。因此，我们要

同时规定任务、衡量结果的标准和程序所用的经验。T. M. Mitchell 的经典定义把这三项合在一起[10]。

[10] T. M. Mitchell, *Machine Learning*, McGraw-Hill, 1997, 1st ed.

> **定义 1.1　机器学习**　对于某类任务 $T$ 和性能度量 $P$，如果一个计算机程序在任务 $T$ 上按 $P$ 衡量的性能因经验 $E$ 而有所改善，就称该程序从经验 $E$ 中进行了学习。

定义 1.1中的三个要素各有具体含义：

- **任务**（task, $T$）说明希望系统完成什么，例如判断邮件是否为垃圾邮件；
- **性能度量**（performance measure, $P$）说明怎样判断任务完成得好不好，例如分类正确的比例或漏放垃圾邮件的数量；
- **经验**（experience, $E$）说明系统从什么信息中学习，例如带人工标签的历史邮件，也可以是没有标签的数据、用户反馈或与环境交互得到的奖励。

改变其中一项，学习问题就可能改变。历史邮件既能用于判断垃圾邮件，也能用于整理主题；一个分类器即使准确率较高，也可能误拦了不能接受数量的正常邮件。定义中的改善，是利用指定经验后按 $P$ 作出的比较判断。$E$ 可以是一整批样本、交互记录或其他反馈，并不限于逐个加入的样本。增加一次经验仍可能使某次评价下降，定义没有要求性能随经验数量逐步、单调地提高。

## 1.2 例子：垃圾邮件分类

现在把任务、经验和性能度量落实到同一个分类过程。我们用已标注的历史邮件选择判断规则，再让选定的规则处理未参与选择的邮件。这样可以依次观察数据准备、建模、训练、预测和评估各自改变了什么。这里的邮件及标签都是教学构造，完整数据与配置见随书脚本 `introduction-spam-example.py`，每次迭代的损失保存在同目录的 `introduction-training-loss.csv` 中。后面报告的是这套构造数据上的计算结果，不能据此估计真实邮件系统的分类效果。

这个系统读取一封邮件中的可用信息，并在垃圾邮件和正常邮件之间作出判断。两个候选类别构成**二分类**（binary classification）问题。历史邮件的已知类别用**标签**（label）记录：垃圾邮件记为 1，称为**正类**（positive class）；正常邮件记为 0，称为**负类**（negative class）。正负名称只是计算约定。表 1.1据此列出本例的任务、性能度量和经验，供后面的训练与评价共同使用。

| 要素 | 在垃圾邮件分类中的含义 |
|---|---|
| 任务 $T$ | 输入一封邮件，输出“垃圾邮件”或“正常邮件”。 |
| 性能度量 $P$ | 考察测试邮件中分类正确的比例，并分别记录误拦正常邮件和漏放垃圾邮件。 |
| 经验 $E$ | 历史邮件、由人工给出的类别标签，以及据此形成的训练反馈。 |

表 1.1 垃圾邮件分类问题的任务、性能度量与经验。三个要素共同规定了“学得更好”的含义。

为了判断训练是否带来收益，我们先指定一个可以直接执行的比较方案，称为**基线**（baseline）。本例的基线始终预测训练集中数量较多的正常邮件。若测试集也以正常邮件为主，它可以靠这一固定答案取得较高准确率，却漏掉全部垃圾邮件。因此，比较时除了准确率，还要分别数出误拦和漏放，才能判断学到的规则解决了什么问题。

### 1.2.1 从邮件到样本与特征

一封原始邮件不能直接成为任意分类模型的输入，我们需要先决定程序能够读取哪些信息。把邮件转换成模型可处理的对象，就得到它的**表示**（representation）；用来描述邮件的各个量称为**特征**（feature）。例如，可以记录发件人和域名、主题与正文中的词语、字符组合、链接、附件、邮件头、发送时间及历史通信关系。现实系统会综合多种信息，某一项线索是否可靠仍取决于环境，不能只凭特征名称判断。

为使预测计算可以手工核对，我们只保留两个计数：正文中的促销提示词次数 $x_1$ 与外部链接数 $x_2$。邮件的输入于是成为 $\boldsymbol{x} = (x_1, x_2)^{\top} \in \mathbb{R}^2$。这两项只提供部分线索。教学数据允许相同或相近计数对应不同标签，真实邮件的类别也不能由这两个数唯一决定。简化表示舍去了发件人身份、语境和附件内容，后面的模型都受到这项信息限制。

把一封邮件的输入与已知标签放在一起，得到一条可供学习的记录 $(\boldsymbol{x}_i, y_i)$，称为**样本**（sample）；$i$ 表示邮件编号。由这些记录组成的集合称为**数据集**（dataset）。表 1.2同时列出原始片段和输入计数，便于检查二者的区别：片段属于收集到的信息，计数向量则是按当前表示规则从中提取的模型输入。

参数和配置都根据数据选择后，再用同一批数据报告成绩，会把选择过程的收益带进评价。我们因此在训练开始前划分三组邮件：**训练集**（training set）用于学习参数，**验证集**（validation set）用于选择训练轮数等配置，**测试集**（test set）留到选择完成后评价。表中的子集列标明每条记录的用途。预处理若需要估计词表或特征尺度，也只能在训练集上拟合。例如，词频筛选和均值计算都属于利用数据作出选择；把测试信息用于这些步骤，就已经破坏了预留评价的分工。

| 编号 | 子集 | 邮件片段 | $x_1$ | $x_2$ | $y$ | 类别 |
|---|---|---|---|---|---|---|
| tr01 | 训练 | “限时优惠，立即领取……” | 3 | 2 | 1 | 垃圾邮件 |
| tr06 | 训练 | “周会改至下午三点” | 0 | 0 | 0 | 正常邮件 |
| tr11 | 训练 | “优惠券报销说明” | 2 | 0 | 0 | 正常邮件 |
| va02 | 验证 | “会员权益，详情见链接” | 1 | 2 | 1 | 垃圾邮件 |
| va03 | 验证 | “本周三场促销培训” | 3 | 0 | 0 | 正常邮件 |
| te02 | 测试 | “两项优惠，见附件链接” | 2 | 1 | 0 | 正常邮件 |
| te07 | 测试 | “专属优惠今日有效” | 2 | 0 | 1 | 垃圾邮件 |
| te08 | 测试 | “优惠详情见两个链接” | 1 | 2 | 0 | 正常邮件 |

表 1.2　教学数据的部分样本。$x_1$ 为促销提示词次数，$x_2$ 为外部链接数，标签 $y=1$ 表示垃圾邮件。训练集、验证集和测试集承担不同职责。

### 1.2.2 对问题进行建模

两个计数还不能给出类别，我们需要约定怎样把它们合成判断依据。本例采用线性得分：每增加一个促销词或链接，得分按对应权重改变。得分可取任意实数，尚没有概率含义。为建立概率模型，记随机特征向量为 $\boldsymbol{X}$，其取值在 $\mathbb{R}^2$ 中；随机标签为 $Y$，其取值在 $\{0,1\}$ 中；$\boldsymbol{x}$ 表示一封邮件的特征实现。把模型参数记为 $\boldsymbol{\theta}=(b,w_1,w_2)^{\top}\in\Theta$，本例取 $\Theta=\mathbb{R}^3$。进一步约定 $Y\mid \boldsymbol{X}=\boldsymbol{x}\sim \mathrm{Bernoulli}(p_{\boldsymbol{\theta}}(\boldsymbol{x}))$：给定邮件特征后，标签为 1 的概率是 $p_{\boldsymbol{\theta}}(\boldsymbol{x})$，标签为 0 的概率是 $1-p_{\boldsymbol{\theta}}(\boldsymbol{x})$。本例用**逻辑函数**（logistic function）把线性得分映射到 $(0,1)$：得分越大，输出越接近 1；得分越小，输出越接近 0。这个计算关系写为

$$z_i=b+w_1x_{i,1}+w_2x_{i,2}, \tag{1.1}$$

$$p_{\boldsymbol{\theta}}(\boldsymbol{x}_i)=f_{\boldsymbol{\theta}}(\boldsymbol{x}_i)=\hat{p}_i=\sigma(z_i)=\frac{1}{1+\exp(-z_i)}. \tag{1.2}$$

这样的分类**模型**（model）规定了输入与输出之间的计算关系。依照上述 Bernoulli 条件假设，$\hat{p}_i$ 才被解释为模型对“第 $i$ 封邮件是垃圾邮件”的概率估计；仅仅把任意得分压到 $(0,1)$ 内，并不足以自动获得概率含义。式中的 $\exp(-z_i)=e^{-z_i}$ 是指数函数；$\sigma$ 是逻辑函数的简写。概率还需要转换成类别：当 $\hat{p}_i\ge 0.5$ 时预测 $\hat{y}_i=1$，否则预测 $\hat{y}_i=0$。这里预先选取 0.5 作为分类**阈值**（threshold），决定多大的垃圾邮件概率会触发拦截。它便于演示，但不表示在误拦与漏放成本不对称时仍然最优。

线性得分中的三个数承担不同作用。**偏置**（bias）$b$ 给出两个计数都为零时的得分；**权重**（weight）$w_1,w_2$ 分别说明促销词或链接增加一个时得分改变多少。需要根据数据确定的这些数称为**模型参数**（model parameters）。一组 $\boldsymbol{\theta}\in\Theta$ 产生一个具体函数，把所有允许参数对应的函数合在一起，就得到**假设空间**（hypothesis space）$\mathcal{H}=\{f_{\boldsymbol{\theta}}:\boldsymbol{\theta}\in\Theta\}$。因此，写出式 (1.2)只确定了候选范围；训练还要在这个范围内选择具体参数。

为什么不从样本直接读出新邮件的答案？因为多种规则可以在已见样本上作出相同判断，却在未见输入上分歧。例如，只查看计数的规则与还

查看发件人的规则，可能同样符合历史记录。即使在限定的逻辑模型中求得唯一参数，唯一性也来自模型形式、损失和选择规则共同施加的限制。本例预先选择两个计数、线性得分、逻辑函数和固定阈值。这些使某些规律优先于另一些规律的选择称为**归纳偏置**（inductive bias）。它规定算法怎样超出有限记录作出判断，也规定了算法不能利用什么。本例对计数相同的邮件总给出相同预测；如果真正的区别在发件人或语境中，再怎样调整权重，也不能恢复表示时已经舍去的信息。

候选规则给出不同概率，要选择参数，就需要一种对每次预测计分的标准。**损失函数**（loss function）给一次预测的错误程度计分，损失越小，表示这次预测越符合目标。本例输出的是概率，这里采用**二分类交叉熵**（binary cross-entropy）：它检查模型给真实类别分配了多少概率，分配得越少，惩罚越大。对于标签 $y_i \in \{0, 1\}$，损失写为

$$\ell(\hat{p}_i, y_i) = -y_i \log \hat{p}_i - (1 - y_i) \log(1 - \hat{p}_i). \tag{1.3}$$

这里 log 取自然对数。以一封真正的垃圾邮件为例，它的标签为 $y_i = 1$，损失为 $-\log \hat{p}_i$。如果模型预测它是垃圾邮件的概率为 0.9，损失约为 0.105；如果预测概率只有 0.1，损失则约为 2.303。这两个数值把惩罚方向具体显示出来：真实类别得到的概率越小，交叉熵损失越大。

参数要服务于整批训练邮件，不能只按一封邮件的得分选择。对于 $n$ 个训练样本，对损失取平均，得到**经验风险**（empirical risk），用它概括模型在整批训练邮件上的错误代价：

$$\hat{R}_{\text{train}}(\theta) = \frac{1}{n} \sum_{i=1}^{n} \ell\big(f_\theta(\boldsymbol{x}_i), y_i\big). \tag{1.4}$$

以 $\Theta$ 为候选范围，按平均训练损失从小到大选择参数，称为**经验风险最小化**（empirical risk minimization, ERM）。如果最小值能够取到，这个目标可以写为

$$\hat{\theta} \in \arg\min_{\theta \in \Theta} \hat{R}_{\text{train}}(\theta). \tag{1.5}$$

这里的 arg min 表示使目标函数达到最小值的参数集合；有限计算下的训练通常只能寻找近似解，而不一定得到这个集合中的参数。损失函数服务于参数学习，性能度量服务于任务评估，二者可以一样，也可以不同。本例用交叉熵来训练模型，但最终对整个任务的结果进行评估还要看在测试数据上的准确率、误拦数和漏放数等指标。

### 1.2.3 根据历史邮件进行训练

经验风险给出比较标准，程序还需要具体的参数更新规则。**训练**（training）就是利用训练数据确定参数的过程。本例采用**梯度下降**（gradient descent）：

计算当前损失的梯度，沿其反方向移动，再在新位置重复计算。从 $\theta^{(0)} = (0,0,0)^{\top}$ 开始，更新规则为

$$\theta^{(t+1)} = \theta^{(t)} - \eta \nabla_{\theta} \hat{R}_{\text{train}}\big(\theta^{(t)}\big). \tag{1.6}$$

上标 $(t)$ 表示第 $t$ 次更新后的参数；$\nabla_{\theta}$ 表示对参数求梯度。梯度给出当前位置的一阶变化方向，反方向是局部下降的选择。**学习率**（learning rate）$\eta$ 控制每一步的幅度，本例取 $\eta = 0.35$。本例的损失函数具有连续的导数，沿非零梯度的反方向走足够小的一步会使损失下降；步子过大则未必如此。

更新公式并不替我们决定所有配置。权重和偏置由式 (1.6)学习，学习率与运行多少次更新则要另外设定。这些控制模型或学习过程的配置称为**超参数**（hyperparameter）。阈值也可以通过验证选择；本例把它预先固定为 0.5，它只参与类别判断，不参与交叉熵更新。我们只比较 $C = \{20, 40, 60\}$ 这三个迭代时点，以验证准确率较高者为优，平局时采用更新次数较少者。这样，模型选择的候选范围、评价量和选择规则都已明确。

**算法 1.1　垃圾邮件分类器的训练**

**输入：** 训练集 $D_{\text{train}}$，验证集 $D_{\text{val}}$，学习率 $\eta$，候选迭代次数集合 $C = \{20, 40, 60\}$，分类阈值 0.5
**输出：** 选定参数 $\hat{\theta}$

初始化 $\theta^{(0)}$
**for** $t = 0, \dots, \max(C) - 1$ **do**
　在训练集上计算经验风险及其梯度
　按式 (1.6)得到 $\theta^{(t+1)}$
　**if** $t + 1 \in C$ **then**
　　按阈值 0.5 在验证集上记录准确率
　**end if**
**end for**
从验证准确率最高的候选中选取迭代次数最小者，记为 $\hat{\theta}$
**return** $\hat{\theta}$

执行一次更新后，参数约为 $(-0.029, 0.102, 0.058)^{\top}$，平均训练损失由 0.693 变为 0.658。这一步降低了训练目标，却还不能决定何时停止。我们在第 20、40 和 60 次更新时分别保存参数，用各自的模型分类 6 封验证邮件，再按既定规则比较。三份参数属于同一种模型形式在不同训练阶段的版本；验证邮件只参与版本比较，始终不参与梯度计算。

三个时点的验证结果为：第 20 和 40 次更新各答对 5 封，准确率为 $5/6$；第 60 次只答对 4 封，准确率为 $4/6$。最高准确率在前两个时点并列，平局规则因此选中第 20 次更新。供后续预测使用的参数为

$$\hat{\theta} = (-1.000,\ 0.692,\ 0.230)^{\top}. \tag{1.7}$$

| $t$ | $b^{(t)}$ | $w_1^{(t)}$ | $w_2^{(t)}$ | 训练损失 |
|---|---|---|---|---|
| 0 | 0.000 | 0.000 | 0.000 | 0.693 |
| 1 | −0.029 | 0.102 | 0.058 | 0.658 |
| 20 | −1.000 | 0.692 | 0.230 | 0.452 |

表 1.3 训练过程中参数与平均训练损失的变化。第 20 次迭代是验证集选定的检查点；表中数值由完整计算结果舍入得到。

继续训练时，图 1.1中的训练交叉熵仍在下降，验证交叉熵也逐渐降低。但第 60 次更新的验证准确率反而低于第 20 次更新。概率改变可以降低交叉熵，也可能使某封邮件越过 0.5 阈值后分类出错。这个计算例子说明，训练目标与类别评价关注的量不同，损失下降不能直接替代准确率检查。

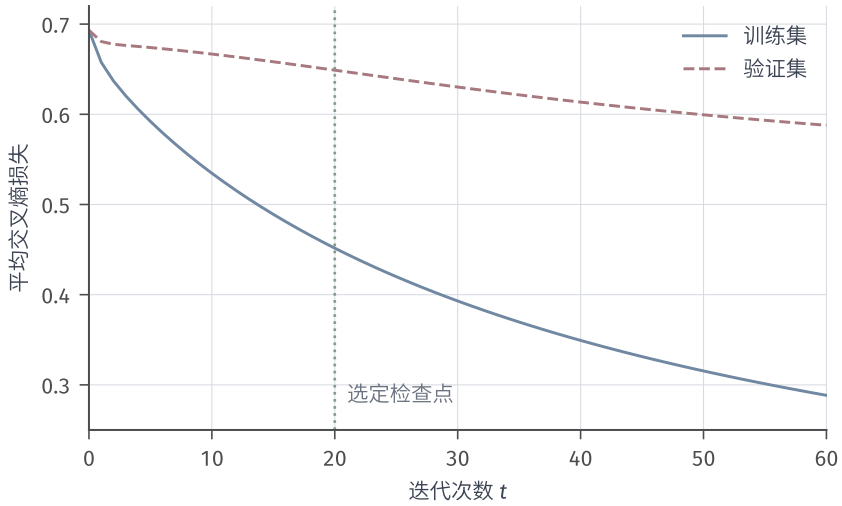


图 1.1 训练集和验证集上的平均交叉熵损失。蓝色实线表示训练曲线，红色虚线表示验证曲线，绿色竖线标出按验证准确率选定的第 20 次迭代；模型选择并非直接读取训练损失的最低点。

这次计算也把模型与算法区分开了。式 (1.2)给出参数化的输入输出关系，**学习算法**（learning algorithm）规定怎样从数据中选出参数。本例算法同时包含梯度更新和验证选择，见算法 1.1。将选出的参数填入模型形式，才得到一个可直接计算的预测函数。这个函数可以反复处理新邮件，参数选择过程无须在每次预测时重复。

### 1.2.4 对新邮件进行预测

现在固定选定参数，读取一封没有参与训练的邮件。用学到的函数计算输出，称为**推理**（inference）。在本例的离线设定中，推理先算垃圾邮件概率，再按阈值给出类别；过程不读取真实标签，也不更新参数。未标注的新邮件和已标注的测试邮件都可以这样计算。二者的差别出现在计算之后：只有取得标签，才能检验预测是否正确。

我们先计算 `new01`，它有两个促销词和两个链接，输入为 $\boldsymbol{x} = (2, 2)^{\top}$。使用已选参数，得到

$$z = -1.000 + 0.692 \times 2 + 0.230 \times 2 = 0.844, \tag{1.8}$$

$$\hat{p} = \sigma(0.844) = 0.699. \tag{1.9}$$

计算所得概率越过 0.5 阈值，所以预测类别为垃圾邮件。表 1.4 列出三个新样本的结果。

| 编号 | 邮件片段 | $(x_1, x_2)$ | $\hat{p}$ | 阈值 | 预测 |
|---|---|---|---|---|---|
| `new01` | “会员优惠，点击两个链接” | $(2, 2)$ | 0.699 | 0.5 | 垃圾 |
| `new02` | “项目文档见共享链接” | $(0, 1)$ | 0.316 | 0.5 | 正常 |
| `new03` | “优惠详情见两个链接” | $(1, 2)$ | 0.538 | 0.5 | 垃圾 |

表 1.4 新邮件的推理结果。概率和类别均由式 (1.7) 中的固定参数计算；真实标签不是推理所需的输入。

能够复现这一结果的，不只是参数向量。训练与推理还必须沿用相同的特征定义和预处理顺序。如果训练时 $x_1$ 来自固定词表，换一份词表后同一邮件的输入可能改变，原参数便不再对应原计算。部署时应一并保存参数、表示规则和阈值，才能保持预测的含义。

### 1.2.5 模型的评估

新邮件的预测还没有可供比较的答案，不能仅凭输出判断效果。我们因此使用此前预留的带标签测试邮件，在参数与阈值固定后逐封预测，再与真实标签对照。表 1.5列出全部 8 封邮件。测试标签只服务于这次评价；若根据结果回头调整参数或配置，这组邮件就参与了选择，失去原先独立检验的作用。

| 编号 | $(x_1, x_2)$ | $y$ | $\hat{p}$ | $\hat{y}$ | 结果 |
|---|---|---|---|---|---|
| `te01` | $(3, 2)$ | 1 | 0.823 | 1 | 识别垃圾邮件 |
| `te02` | $(2, 1)$ | 0 | 0.649 | 1 | 误拦正常邮件 |
| `te03` | $(1, 3)$ | 1 | 0.594 | 1 | 识别垃圾邮件 |
| `te04` | $(0, 0)$ | 0 | 0.269 | 0 | 放行正常邮件 |
| `te05` | $(0, 2)$ | 0 | 0.368 | 0 | 放行正常邮件 |
| `te06` | $(1, 0)$ | 0 | 0.424 | 0 | 放行正常邮件 |
| `te07` | $(2, 0)$ | 1 | 0.595 | 1 | 识别垃圾邮件 |
| `te08` | $(1, 2)$ | 0 | 0.538 | 1 | 误拦正常邮件 |

表 1.5 独立测试集上的逐样本预测。测试标签只用于比较，不参与参数、迭代次数或阈值的选择。

逐行计数得到 6 次正确分类，准确率为 $6/8 = 75\%$。3 封垃圾邮件全部被识别，同时有 2 封正常邮件遭到误拦。相同测试集上，始终预测正常的基线答对 5 封，准确率为 62.5%；它没有误拦，却漏放了 3 封垃圾邮件。训

练提高了这里的准确率并减少漏放，也增加了误拦。应用是否接受这一取舍，要由两类错误的实际代价决定。

| 方法 | 准确率 | 误拦数 | 漏放数 |
|---|---|---|---|
| 学到的线性模型 | 75.0% | 2 | 0 |
| 全部预测为正常 | 62.5% | 0 | 3 |

表 1.6 学到的模型与基线在同一测试集上的比较。单个指标不能完整表达两类错误的代价。

测试让我们从训练记录转向未参与学习的样本，这正是**泛化**（generalization）所关注的范围。如果模型追随了训练集的偶然细节，在训练数据上错误很少，在同一来源的新样本上错误却明显增多，就存在**过拟合**（overfitting）。如果训练与新样本上的结果都差，模型可能没有学到数据中的主要规律，称为**欠拟合**（underfitting）。表达限制和训练不足都可能造成后一情形；一次较差的测试成绩还不能区分这些原因。

我们需要分别检查训练目标是否降低，以及新样本上的预测是否改善。限制模型追随偶然细节的一种方式是**正则化**（regularization）：在选择参数时加入约束，例如惩罚过大的权重。训练目标于是同时比较拟合程度和参数大小。这会改变候选参数的取舍，收益是否符合当前任务，仍应通过验证数据判断。

同一来源的新样本也不是所有未来邮件。发送者更换措辞、用户群体改变，或部署渠道不同，都可能改变输入与标签出现的规律。这种改变称为**分布变化**（distribution shift）。即使模型没有过拟合，旧测试数据也可能不能代表新的使用环境。补充数据、改变表示或重新训练是否必要，要通过持续评价判断。输入和人群监测能提供线索，延迟取得的标签或抽样复核则能直接检查预测错误；只看无标签输入和模型输出，可能遗漏质量下降。

从历史记录到预测规则，我们已经完成表示、参数学习与模型选择；独立测试又把收益和错误分开呈现。换成其他应用时，这些环节仍然存在，但输入、所需结果和错误代价会改变。下面分别整理任务、经验与性能度量，说明邮件案例中哪些选择可以推广，哪些必须随问题重定。

## 1.3 任务

一批用户评论可以用于判断满意度、提取产品名称，也可以用于生成摘要。同样的材料并不规定唯一的工作。因此，描述任务时要说明系统读取什么、产生什么结果，以及结果的使用情境。怎样评价这些结果仍由性能度量 $P$ 规定，任务 $T$ 不代替评价标准。我们先观察不同应用要求的输出，再提炼可以跨应用复用的任务形式。

### 1.3.1 应用场景中的任务

**自然语言处理** 客服收到一句“我的订单什么时候到”，可能需要判断查询意图、找出订单信息或组织答复。输入都是语言，所需输出却不同。**自然语言处理**（natural language processing, NLP）用计算方法分析和生成人类语言；以下文本例子说明输出要求如何决定任务。

如果答案是预先规定的一类，就可以采用**文本分类**（text classification）。例如，**情感分析**（sentiment analysis）把“送货很快，包装也完好”判为正面评价，**垃圾信息检测**（spam detection）判断消息是否属于垃圾内容，**意图识别**（intent recognition）把订单到达时间的询问归为物流查询。若手中只有反馈文本，还没有给定类别答案，可以按内容关系分组，再观察各组对应的主题。这称为**文本聚类**（text clustering）。分类依据已规定的类别作答，聚类则探索尚未确定的分组。

一句话的整体类别有时不足以完成处理。系统还可能需要说明每个词或片段的作用，因而采用**序列标注**（sequence labeling），为文本各位置赋标签。**词性标注**（part-of-speech tagging）判断名词、动词等词类；**命名实体识别**（named entity recognition）定位人名、机构名、地名等片段并给出类型，也常借助这种任务形式。

标出了片段，还可以进一步建立可使用的事实记录。**信息抽取**（information extraction）从文本中取得实体、关系等结构化信息。在“小林就职于星海公司”中识别人名与机构后，**关系抽取**（relation extraction）判断二者的任职关系，可将实体对作为输入进行关系分类。序列标注与联合抽取的多个输出部分互有联系，因此属于**结构化预测**（structured prediction）：预测结果是一个有内部关系的整体，而非互不关联的单个答案。

文字不同也可能表达同一需求。“如何退货”和“商品不想要了怎么退”能否使用同一答复，需要比较含义。**语义匹配**（semantic matching）判断文本是否意思相近，或查询是否与文档相关。若只输出匹配与否，任务是分类；若估计连续的相似程度，可以作为**回归**（regression）；若据此排列候选文档，则属于**排序**（ranking），关注相对次序。**自然语言推断**（natural language inference）考察陈述间的关系，常用蕴含（entailment）、矛盾（contradiction）和中性（neutral）表示前文支持后文、彼此冲突或信息不足。例如，按通常语境，“一名运动员正在跑步”支持“有人正在运动”。这里的判断依赖语言背景，不能直接等同于形式逻辑的演绎。

输出也可以是一段新文字。**文本生成**（text generation）根据输入要求组织文本；**机器翻译**（machine translation）在保留含义的前提下转换语言，**文本摘要**（text summarization）从长文中形成短概述，**智能问答**（question answering）根据问题和资料形成答案。用输入限定生成结果时，称为**条件生成**（conditional generation）。这些应用并不只有生成这一种表述：**抽取**

**式摘要**（extractive summarization）选择原文句子，可以采用分类或排序；选取材料中的答案片段，则可以采用信息抽取。**生成式摘要**（abstractive summarization）和**生成式问答**（generative question answering）才要求模型自行组织输出文字。

**图像处理** 照片也可以支持不同的输出要求。相册管理要判断照片属于海滩还是街道，道路感知还要定位行人和道路。**图像处理**（image processing）以图像或视频帧为对象，其中的学习任务既可以识别内容，也可以生成和恢复图像。

要给整幅图像赋类别，可以采用**图像分类**（image classification）。相册按海滩、街道或室内场景分类，质检系统判断表面是否有缺陷，都是这类任务。输出可以是一个类别，也可以包含多个类别；这种要求通常不包括对象的具体坐标。

道路上是否有行人与行人在何处，是两个不同问题。**目标检测**（object detection）同时预测对象类别和位置，常用包围对象的矩形，即**边界框**（bounding box），定位汽车、行人或交通标志。类别由分类预测，框的位置和大小常由回归预测。图中对象数目也可能变化，所以完整输出是一组检测结果，需要同时确定数量与对应关系。

若要知道道路或器官的精确轮廓，矩形框又过于粗略。**图像分割**（image segmentation）把输出细化到像素区域。**语义分割**（semantic segmentation）给每个像素道路、建筑或天空等类别，可视为有关联的像素分类；**实例分割**（instance segmentation）进一步分开同类对象，例如为每位行人保留各自轮廓。医学影像中勾画器官，也需要这类比大致位置更细的区域信息。

分析动作还要说明身体各部位的排列。**姿态估计**（pose estimation）预测关键位置或空间姿态；人体的肩、肘、膝等明确位置称为**关键点**（keypoint）。这些位置用于描述动作并支持运动分析和人机交互。可以直接回归坐标，也可以先预测关键点在各位置出现的可能性，再确定位置。各点之间受到身体结构关系约束，因而整个结果同样属于结构化预测。

以图像为输出时，还要区分产生新内容与恢复已有观测。按文字绘制插图属于**图像生成**（image generation）；根据受损或不完整观测去噪、补全区域、提高分辨率，则属于**图像重建**（image reconstruction）。重建可以回归像素，也可以在观测约束下进行条件生成。观测丢失了信息时，可能存在多个符合约束的结果，生成的细节未必就是原场景中的细节。

**推荐、搜索与广告** 电影应用可以在用户尚未输入片名时，依据观看记录、评分和当前情境，主动给出待观看列表。这样的过程称为**推荐**（recommendation）：从大量物品中选择可能对用户有用的对象并呈现。“物品”可以

是电影、商品或新闻。这里的困难是需求尚未被完整表达，系统需要从行为与情境推测当前兴趣，再决定展示什么。

用户也可能直接输入“适合孩子看的太空电影”。**搜索**（search）以这样的查询为线索，从内容集合中查找满足信息需求的对象。查询既可以是词语或句子，也可以是图片。搜索电影时，系统读取查询与电影资料，输出相关电影列表，属于**信息检索**（information retrieval）[11]。它需要在有限时间内理解查询条件、取得候选，并让较相关的结果排在前面。

[11] C. D. Manning, P. Raghavan, H. Schütze, *Introduction to Information Retrieval*, Cambridge University Press, 2008

若页面还允许广告主付费推广，选择对象就增加了参与方与限制。**广告**（advertising）从有投放资格的广告中分配展示机会，除了判断用户可能作出的响应，还要处理广告主的受众条件、出价和预算，以及平台审核、计费和用户体验规则。系统需要先判断资格，再估计点击或购买等价值，最后在资源与规则约束下决定展示和收费，并检验产生的效果。

推荐、搜索和广告都从大量对象中选择，因而可以共享用户信息、内容特征与交互记录，并复用理解需求、取得候选、预估价值、排序和利用反馈等环节。不过，三者对同一对象的判断可能不同。喜欢科幻片的用户可能愿意看太空惊悚片，但它未必满足“适合孩子”的查询；与兴趣相符的广告，还要经过审核并满足定向和预算条件。推荐主要推测潜在需求，搜索受当前查询约束，广告还受到付费关系与资格规则约束。共享计算环节并不使这些目标等价。

把这些目标分解到可计算的环节后，才能说明机器学习具体预测什么。我们沿需求理解、候选筛选和结果展示的依赖顺序考察，每一步都要交代输入、输出与用途。

搜索先需要从查询中取得对象和条件，称为**查询理解**（query understanding）。对“适合孩子看的太空电影”，文本分类可以识别找电影的意图，信息抽取或序列标注可以取出太空题材和孩子这一受众条件。输入是查询文本，输出的类别或片段为检索提供依据。推荐则从历史行为与当前情境估计兴趣；广告还要解析受众条件和内容。它们共同为后续匹配形成需求侧与对象侧的表示。

有了需求表示，仍不宜对全部内容作精细计算。**候选生成**（candidate generation），也称**候选召回**（candidate retrieval），先选出一小批可能有用的对象，以限制后续计算。推荐匹配用户与物品，搜索匹配查询与物品；广告还要先执行审核、定向和预算筛选。模型可以利用交互或相关性标签学习匹配得分，例如比较用户兴趣与电影资料、查询与电影简介，或用户情境与广告信息。得分用来筛选集合，留下有用且合格的对象，再交给后续环节。

留下候选后，可以进一步估计用户的评价与行为。**评分预测**（rating prediction）读取用户和物品信息，估计评分数值，通常可用回归表述。**点**

**击率预测**（click-through rate prediction）估计展示后发生点击的概率，历史点击与未点击记录可以作为二分类标签。**转化率预测**（conversion rate prediction）估计在约定条件下购买等行为的概率，例如点击商品后购买的概率。三类应用都可能使用这些量，但点击概率只回答点击问题，不能直接代表查询相关性、用户满意度或广告的增量效果。

候选的分数最终要支持一份有次序的列表。**学习排序**（learning to rank）根据相关性标签、偏好或交互反馈学习次序，例如让儿童科幻片排在太空惊悚片之前，以满足当前查询。模型读取需求与候选信息，产生得分或相对次序，评价则关注有用结果的位置。推荐比较当前用户的物品价值，搜索比较查询相关性，广告还须结合出价、预算和展示限制。竞价与分配同时处理展示资格和计费，超出了预测分数排序。最终列表还可以经过**重排序**（reranking）或混合编排，减少重复、兼顾多样性或限制广告密度；这些调整既可使用模型，也可依据明确规则[12]。

历史行为的时间顺序也可能影响当前选择。**序列推荐**（sequential recommendation）根据按时间排列的记录预测下一次兴趣：连续浏览儿童动画后，用户当前需求可能偏离长期偏爱的科幻题材。只预测下一项时，可以使用分类或排序；若还要评价当前展示对后续观看和长期体验的影响，就要比较多次行动的后果，形成**序贯决策**（sequential decision making）。广告预算消耗和重复曝光同样会影响后续机会，当前收益便需要与未来机会一起考虑。

这些环节的输出可以成为下一环节的输入：需求与对象表示支持匹配，候选集合缩小比较范围，行为预测支持排序，排序、竞价或编排决定展示，反馈再支持调整。但学习模型并非每一步的必要条件，关键词检索和广告资格规则仍可直接执行。尤其要检查交互标签如何产生。前排结果更容易被看到和点击，因此点击量同时受到位置与既有展示策略影响，不能直接解释为相关性、偏好或广告效果[13]。

**其他领域** 上述输入虽有差别，分类、数值预测和行动选择却可以反复出现。科学研究与工业系统也会提出相近任务，只是观测形式与使用约束不同。下面用生命科学、自动化与控制、语音处理说明这种跨领域复用。

生命科学（life sciences）可以从细胞测量、基因表达（gene expression）和分子结构形成输入。**细胞类型识别**（cell type identification）按测量特征判断类别，属于分类；按基因表达模式组织细胞，则可采用聚类。**分子性质预测**（molecular property prediction）估计溶解度等数值性质，可采用回归；**分子生成**（molecular generation）根据所需性质提出结构，属于生成。模型的预测与候选结构仍需要领域知识和实验验证，计算输出并不完成科学确认。

[12] Google, *Recommendation Systems Overview*, Aug. 25, 2025, URL: https://developers.google.com/machine-learning/recommendation/overview/types

[13] T. Joachims, A. Swaminathan, T. Schnabel, *Unbiased Learning-to-Rank with Biased Feedback*, 2016, arXiv: 1608.04468, URL: https://arxiv.org/abs/1608.04468

| 层次 | 任务 | 典型输出 | 任务要求 | 例子 |
|---|---|---|---|---|
| 基础 | 分类 | 一个或多个离散类别 | 判断输入属于哪些类别 | 垃圾邮件识别、图像分类 |
| 基础 | 回归 | 连续数值 | 使预测值接近目标数值 | 评分预测、需求预测 |
| 基础 | 聚类 | 样本的组别或结构 | 按相似性探索分组结构 | 文档主题探索、用户分群 |
| 基础 | 降维 | 低维表示 | 用较少变量保留主要结构 | 数据可视化、压缩 |
| 复合 | 排序 | 相关性分数或候选次序 | 把更有用的对象排在前面 | 文档检索、推荐排序 |
| 复合 | 生成 | 文本、图像、音频等对象 | 产生符合条件或规律的内容 | 摘要、翻译、图像生成 |
| 复合 | 结构化预测 | 相互关联的标签或数值 | 联合满足输出内部关系 | 序列标注、目标检测 |
| 复合 | 序贯决策 | 随状态变化的一系列行动 | 提高一段时间内的累计回报 | 机器人控制、交互式推荐 |

表 1.7 四类基础任务与常见复合任务。复合任务可以调用基础任务，但其整体输出与评价目标不能由局部任务替代。

自动化与控制系统（automation and control systems）也可以把观测转为明确任务。**故障诊断**（fault diagnosis）依据传感器记录判断故障类别；**系统辨识**（system identification）从记录学习动态关系，例如由当前温度与加热功率预测后续温度，其中的数值输出可用回归。机器人控制则随环境与自身状态连续选择动作，属于序贯决策，常把感知、状态预测与行动选择合在一起。

**语音处理**（speech processing）改变的是输入输出材料。**语音识别**（speech recognition）把连续音频转换成文字序列，涉及**序列预测**（sequence prediction）；**语音合成**（speech synthesis）按文本产生音频，属于条件生成。

我们因此可以把**应用场景**（application scenario）理解为问题的使用环境，把任务理解为系统在其中必须完成的具体工作。同一场景可以包含数项任务，同一任务形式也可以服务多个场景。

### 1.3.2 常见任务类型

从这些应用中，可以按基本输出整理出**分类**（classification）、回归、聚类和降维四类任务：它们分别给出类别、数值、分组和低维表示。排序、生成、结构化预测和序贯决策的输出或目标更复杂，可以在局部调用这四类任务，但仍要单独规定完整结果的要求。例如，用分类预测词元可以支持文本生成，逐个词元的准确率却不能完整评价一段文字。表 1.7列出这种基础与复合关系；这里的“基础”用于说明可分解的计算职责，不能据此把复合任务等同于某一种基础任务。

分类先由任务规定类别集合及其含义，再判断输入属于哪一类或哪些类。邮件二分类（binary classification）在垃圾与正常之间选择；**多分类**（multiclass classification）可以在正面、负面、中性等互斥类别中选择；**多标签分类**（multilabel classification）则允许一张照片同时带有海滩、日落和人物标签。模型需要从输入找出区分类别的依据，类别名称本身并不提供判断规则。

实际分类器常先计算分数或概率，再用最大分数、阈值等规则给出类别。连续的中间分数仍服务于离散决策，并不会把最终任务改成回归。类别比例、错误代价与标签能否同时出现，会影响决策和评价方式。若逐词或逐像素分类，输出位置之间还可能有关联，完整任务就需要处理这些关系。

回归把输出改为连续数值，例如价格、用电量、观看时长或未来温度。模型可读取一条记录或一段历史，预测一个数或一组有关联的数。数值相差多少通常比落入哪个类别更重要；因此，还要根据量纲与使用代价，决定用绝对差、平方差还是相对差评价误差。

一个预测温度只给出了点预测，还没有说明温度可能波动多大。需要不确定性时，必须另加分布或预测区间及对应评价。分类中的连续得分则只用于支持类别决策，不能仅凭数值输出判断任务。也可以把连续目标切成区间后分类，但区间内差异随之被舍去，原来比较误差大小的标准也发生了变化。

没有预先给出的类别答案时，可以从样本关系探索分组，称为**聚类**（clustering）。输入是一批样本及其表示，输出可以是组别，也可以是层次结构。形成分组前，要先规定怎样比较样本：文档可用词语或语义表示，用户可用行为或属性。表示、相似性或分组目标改变，同一批记录的分组也可能改变。

分组还需要决定数量与归属方式。组数可以预先设定，也可以由数据与停止规则共同决定；每个样本可以只归入一组，也可以对多个组保留归属程度。由于没有预定的唯一组别答案，评价应检查组内集中、组间分离、对数据变化的稳定性或后续分析用途，不能直接套用分类准确率。分类与聚类虽都能输出组别，区别在于组别体系是任务给定的，还是从样本关系探索得到的。

若困难来自输入变量太多，可以用**降维**（dimensionality reduction）把 $\boldsymbol{x} \in \mathbb{R}^d$ 变成 $\boldsymbol{z} \in \mathbb{R}^k$，其中 $k < d$。较少变量有利于显示、存储和后续计算，同时也舍弃了部分信息。要选择降维结果，必须说明保留目标：重建输入、保持距离或邻域，以及保留区分类别所需信息，提出的是不同要求。

这些要求未必同时满足。适合二维显示的表示可能难以精确重建，保留总体变化最大方向也可能舍去少数类别的线索。降维产生的新表示可以交给分类、回归或聚类，而聚类本身产生分组。两者能够组合，但改变表示也会改变距离和分组，所以应按照实际后续用途检查信息保留与损失。

排序最终比较候选次序，分数的绝对大小未必是评价目标。得到次序可以采用不同的训练对象。**逐点方法**（pointwise approach）分别预测每个候选的相关类别或程度，再据分数排列；**成对方法**（pairwise approach）比较两个候选谁应在前，可将这一关系作为二分类；**列表方法**（listwise

approach）则按整个列表的结果组织学习。这些转化使分类与回归工具可用于排序，但结果仍应按候选位置评价。

**生成**（generation）需要产生文本、图像或音频等整体对象。自回归文本生成可反复分类下一个词元，连续信号生成可调用回归，并利用降维或聚类得到的表示；完整评价仍关注对象是否符合条件和数据规律。结构化预测也组合局部任务，例如目标检测结合类别与位置预测，序列标注还要处理相邻标签关系。序贯决策则将范围扩展到多次行动：分类可选择动作，回归可估计回报，聚类或降维可概括状态，但最终要比较一段时间内的累计收益。

基础任务因而提供了可以组合的计算部件，并不替代应用目标。推荐可以先估计点击概率，检测可以同时分类与回归，低维表示可以继续用于分组。每次分解都要检查局部输出是否保留原问题需要的信息，并按完整任务评价最终结果。

### 1.3.3 任务与学习范式

固定文本分类任务后，仍然可以改变学习方式。我们可以直接使用带标签文本，也可以先从无标签文本学习表示，再利用少量标签训练分类器。两种方式要得到相同类型的答案，却使用了不同经验和反馈。**学习范式**（learning paradigm）描述这些经验与训练的组织方式，与规定输入输出的任务分别承担职责。

在邮件案例中,已知类别直接提供学习目标,这属于**监督学习**(supervised learning)。若只按无标签文本探索结构，则采用**无监督学习**（unsupervised learning)；若从文本自身构造预测目标，则属于**自监督学习**(self-supervised learning)。在同一任务中结合少量标签和大量无标签记录，可采用**半监督学习**（semi-supervised learning)。行动问题又提供另一类反馈：依据后果与奖励调整决策属于**强化学习**（reinforcement learning)，主要依据动作示范学习则属于**模仿学习**（imitation learning)。若经验陆续到达，还要在更新中保留所需旧能力，这由**持续学习**（continual learning）研究。它们限定的维度不同，正式边界和组合关系将在后续章节展开。

描述系统时，应把使用环境、所需结果和学习方式分别说清。一个场景可以包含多种任务，一项任务也可以利用不同形式的经验学习。第 3章将用这些区分建立范式之间的比较依据。

## 1.4 经验

邮件模型利用的不只是数字数量，还包括记录里保留的信息和这些信息的用途。样本、反馈与交互中可供学习使用的部分构成经验，数据是它们在系统中的载体。我们需要说明现实对象怎样被记录、记录怎样转换为算法

输入，以及它来自什么总体并允许用于哪些环节。表示约束可见信息，来源与分布约束总体判断，数据划分约束选择与评价。

### 1.4.1 数据、样本与表示

邮件案例中，一封实际邮件是原始对象，保存的正文、发件人、时间和附件字段是记录；计数规则再把记录转换为模型输入 $\boldsymbol{x}_i$，与标签 $y_i$ 组成样本 $(\boldsymbol{x}_i, y_i)$。这样形成的数据集只是一种经验形式。语音和传感器记录可能按时间排列，推荐记录可能同时包含用户、物品与交互，无标签对象、偏好对、行动轨迹和奖励也能参与学习，不必都简化为输入与单个标签的配对。

用 $o$ 记待处理对象，规则 $r$ 把它转换为 $x = r(o) \in X$。这一步确定算法能够看到的区别。词数与链接数容易解释，却没有词序和语境；像素保留空间采样值，却没有直接标出对象边界；类别编号用来区分身份，其大小通常不表达距离。表示因此会改变学习问题的信息范围。若所需线索在转换中丢失，后续模型无法仅从相同输入恢复对象之间被舍去的差异。

手工计数之外，还可以用已有编码器把对象转换成向量。记这一映射为

$$e_\theta : X \to \mathbb{R}^d, \qquad \boldsymbol{z} = e_\theta(x),$$

其中 $d$ 是嵌入维数，$\theta$ 是编码器参数。如果这个映射把对象转换为向量，并让向量的距离、夹角、邻域或坐标参与后续计算，就把 $\boldsymbol{z} \in \mathbb{R}^d$ 称为**嵌入**（embedding）。例如，文本编码器可以把一段话转换成向量，检索系统再比较查询与文档嵌入的相似程度。坐标未必有可单独命名的含义，几何上的接近也要由训练目标、数据和使用方式支持，不能只因输出是向量就解释为语义相近。两个对象也可能得到相同表示，所以这里的“嵌入”不默认具有数学中一一映射或无失真的含义。

映射是否参与当前训练，决定嵌入在学习问题中的位置。固定编码器先把样本变为 $\boldsymbol{z}_i$ 时，向量可以作为当前算法的输入经验，但仍受上游数据、目标和版本限制。如果编码器 $e_\theta$ 与预测头 $g_\phi$ 联合学习，完整模型是 $h(x) = g_\phi(e_\theta(x))$；$\boldsymbol{z}$ 是计算得到的中间表示，$\theta$ 和 $\phi$ 都要从当前数据确定。训练所得的嵌入不能倒算为训练之前已有的信息。第 2章说明表示模块与任务输出的关系，第 3章说明反馈怎样用于学习表示。

### 1.4.2 数据来源、分布与质量

有限邮件为什么能够用于评价未来？需要先规定记录与未来邮件遵循什么共同规律。**数据分布**（data distribution）给输入和标签的各种组合赋概率，描述哪些情形更常出现；数据集只是按某种采样方式留下的有限记录。二者之间的关系来自采样条件，不能仅凭记录数量建立。

常用分析把这一关系简化为**独立同分布**（independent and identically distributed, i.i.d.）：各样本没有统计依赖，并分别服从同一概率规律。这两项条件支持许多经典统计工具。相邻传感器读数却可能相关，不同用户可能服从不同规律，邮件写法也可能随时间改变。面对这些情况，需要明确依赖、群组或变化，再选择相应工具；独立同分布不成立并不等于数据不能分析。

即使无法精确写出分布，也能检查记录是否覆盖目标场景。来自同一狭窄渠道的大量样本，仍可能缺少某类用户、设备或环境。测量误差与标注分歧影响可靠性，类别不平衡则会让少量重要事件在总体计数中被掩盖。补充数据时，应据目标范围查找缺失情形，并检查测量和标签；仅重复已有来源未必补上这些缺口。

### 1.4.3 数据划分与使用边界

还需要规定数据在什么阶段可见。邮件案例保留三组记录，使参数学习、配置选择和最终检验各用其允许的信息：

- 训练集用于学习模型参数，也用于拟合词表、归一化系数等预处理规则；
- 验证集用于选择超参数、比较候选模型和决定何时停止训练；
- 测试集在所有选择完成后估计最终系统对未见数据的表现。

划分方式也应对应要推广的对象。图 1.2按时间组织数据，适用于预测后续邮件的设定。随机划分常用于近似同分布数据；若要评价未来时段，或推广到未见用户，就应按时间或用户划分，避免让未来信息或同一用户记录同时影响训练和测试。

一旦选择过程使用了原本预留的信息，就发生**信息泄漏**（information leakage）。邮件副本跨入训练与测试两组，可能让模型靠记忆答对；用全体记录拟合词表，也把测试信息用于了输入选择。反复看测试结果再改模型，同样使最终选择依赖这组测试。它便不能继续充当独立证据。评价之所以可能过于乐观，是因为学习时利用了部署阶段未必能取得的未来记录或答案。

避免泄漏只恢复了选择与评价的分工，还没有保证测试分布代表所有未来环境。用户、设备或时间范围改变后，仍应重新验证并监测。解释成绩时，要把数据来源、生成过程与使用条件同记录本身一起报告。

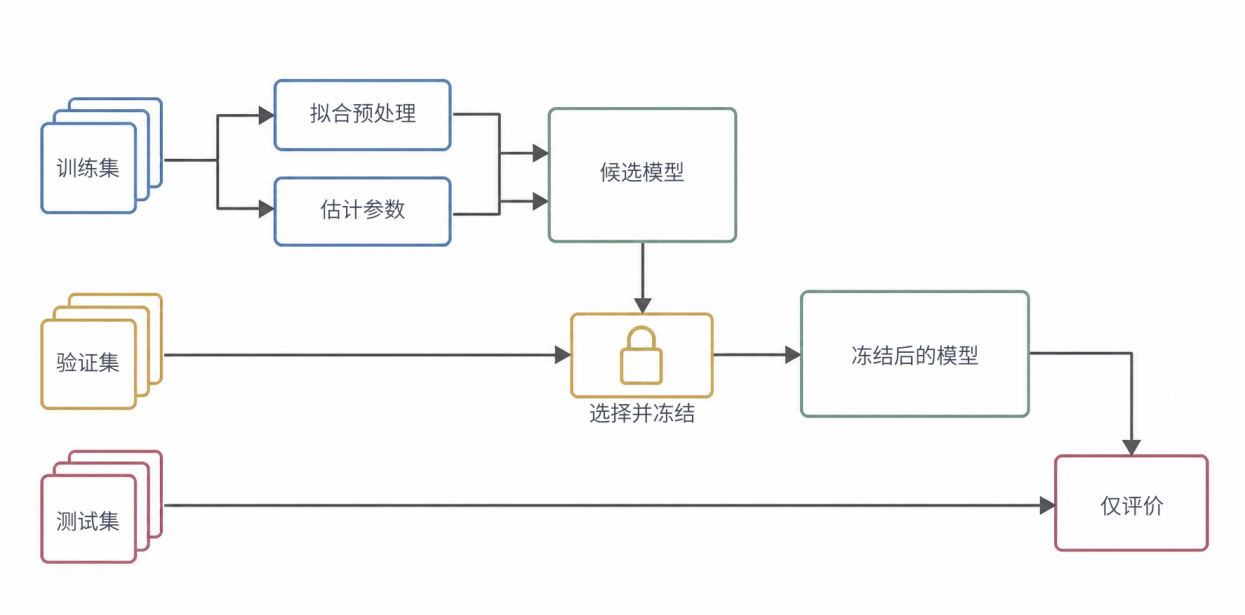


图 1.2 训练集、验证集和测试集的用途。箭头表示各数据集参与拟合、选择与评价的路径；记录数量仅作示意，不代表划分比例。训练集用于参数学习与预处理拟合，验证集用于配置和停止位置的选择，测试集在这些选择冻结后才用于最终评估。

## 1.5 性能度量

误拦重要邮件与漏放广告可能造成不同代价。要把这种应用要求转为数量，先确定哪些结果需要分别比较，再选择指标与基线。只汇总正确比例会掩盖两类错误的构成，因而不足以决定是否采用系统。

把真实类别与预测类别交叉计数，就能区分这两类错误。这张表称为**混淆矩阵**（confusion matrix），四格分别记录两种正确判断和两种错误。垃圾邮件为正类时，真正例（true positive, TP）是正确拦截，假正例（false positive, FP）是误拦正常邮件，假负例（false negative, FN）是漏放垃圾邮件，真负例（true negative, TN）是正确放行。表 1.8由此前表 1.5逐行计数，因而可以直接复核。

| | | **预测类别** | |
|---|---|---|---|
| | | 垃圾邮件 | 正常邮件 |
| **真实类别** | 垃圾邮件 | TP = 3 | FN = 0 |
| | 正常邮件 | FP = 2 | TN = 3 |

表 1.8 垃圾邮件测试结果的混淆矩阵。行表示真实类别，列表示预测类别；“垃圾邮件”被约定为正类。

这四格支持三种不同的比例：全体邮件中答对的比例、被拦邮件中确属垃圾的比例，以及垃圾邮件中被识别的比例。三者分别称为**准确率**（accuracy）、**精确率**（precision）和**召回率**（recall）。$F_1$ **值**（F1 score）用精

确率和召回率的调和平均数综合二者，较小的一项会限制这个综合值。按上述分母取比例，计算为

$$\text{准确率} = \frac{\mathrm{TP}+\mathrm{TN}}{\mathrm{TP}+\mathrm{FP}+\mathrm{FN}+\mathrm{TN}}, \tag{1.10}$$

$$\text{精确率} = \frac{\mathrm{TP}}{\mathrm{TP}+\mathrm{FP}}, \tag{1.11}$$

$$\text{召回率} = \frac{\mathrm{TP}}{\mathrm{TP}+\mathrm{FN}}, \tag{1.12}$$

$$F_1 = \frac{2\times \text{精确率}\times \text{召回率}}{\text{精确率}+\text{召回率}} = \frac{2\mathrm{TP}}{2\mathrm{TP}+\mathrm{FP}+\mathrm{FN}}. \tag{1.13}$$

在本例中, 准确率为 $6/8 = 0.75$, 精确率为 $3/5 = 0.60$, 召回率为 $3/3 = 1.00$, $F_1 = 0.75$。召回率为 1 说明测试集里的垃圾邮件都被识别出来；精确率只有 0.60 说明被拦截的 5 封邮件中有 2 封其实是正常邮件。使用这些公式时还需检查分母：如果没有邮件被预测为正类，精确率就不能直接按此计算；如果测试集中没有正类，召回率也同样如此。采用右侧等价式时，分母为零表示 $\mathrm{TP}=\mathrm{FP}=\mathrm{FN}=0$，本书将 $F_1$ 报告为“不适用”而不任意置零。使用软件工具时也应说明其退化情形约定。

准确率如何掩盖少数类别，可以用一个构造例子看清：一万封邮件中若只有十封垃圾邮件，全部放行也有 99.9% 准确率，却没有识别任何垃圾邮件。精确率与召回率改用不同分母，分别暴露误拦与漏放，但 $F_1$ 仍没有直接计入实际代价。固定概率输出而提高阈值，拦截集合只会缩小或不变，召回率不会增加；精确率是否增加，取决于被排除的两类邮件比例。因此，应在验证集上依据代价选阈值，测试数据只检验选定结果。

对数值预测,评价可以从预测与真实值的偏差建立。**平均绝对误差**（mean absolute error, MAE）对偏差的绝对值取平均，**均方误差**（mean squared error, MSE）则对偏差的平方取平均。对 $n$ 个评估样本，记真实值为 $y_i$、预测值为 $\hat{y}_i$，则

$$\mathrm{MAE} = \frac{1}{n}\sum_{i=1}^{n}|\hat{y}_i - y_i|, \tag{1.14}$$

$$\mathrm{MSE} = \frac{1}{n}\sum_{i=1}^{n}(\hat{y}_i - y_i)^2. \tag{1.15}$$

平方相对于绝对值更强调较大的偏差，两个指标因此给出不同误差权重。排序、生成和序贯决策也各有相应指标，评价时还可能需要结合人工判断、延迟、资源消耗和长期影响。本章不逐一罗列，而强调指标必须与任务和使用条件相匹配。

上述计数和平均量来自有限测试记录，应用关心的却是目标环境里的预测。式 (1.3) 给出一次预测的损失，式 (1.4)把它在训练集上取平均，得到经验风险。为描述这个总体目标，我们按未来输入和标签的概率规律取

平均，得到**期望风险**（expected risk，也称 population risk），即模型在目标分布上的平均损失。记随机输入及其标签为 $(\boldsymbol{X}, Y)$，目标分布为 $\mathcal{P}$，则

$$R(\theta) = \mathbb{E}_{(\boldsymbol{X},Y)\sim\mathcal{P}}\left[\ell\left(f_\theta(\boldsymbol{X}), Y\right)\right]. \tag{1.16}$$

式中的 $\mathbb{E}$ 表示取期望，也就是按各种情形出现的概率对损失加权平均。目标分布一般不能直接读取，独立测试记录因而用于估计这一平均量或对应任务指标。这个估计只适用于相应的采样条件，不能保证任意未来环境中的表现。比较模型时，应使用相同的数据划分、可用信息和评价口径。预处理方案与阈值可用验证集选择，词表、均值等参数仍只用训练集拟合。报告时应交代选择方式与估计的不确定性。

## 1.6 本章小结

从有限经验得到新输入的预测，需要几项选择共同作用：表示决定保留什么信息，模型假设规定候选关系，算法利用记录选出具体模型。检验时，再固定参数与配置，用没有参与选择的记录计算任务指标。邮件案例完成了这个过程，既得到可执行的分类规则，也暴露了误拦代价。它提供了检验泛化的方式，但训练或测试成绩都没有单独证明规则对所有未来邮件有效。

任务、经验和性能度量共同规定了学习问题，数据与未来使用环境的关系则决定成绩可以解释到哪里。模型相比基线减少漏放，同时增加误拦，因此改进必须按具体目标判断。理论部分将在明确假设下研究算法能否达到规定风险标准；可信性部分还要检查标准是否覆盖真实后果，以及群体、环境、权限和攻击变化后的要求。前一问题需要学习保证，后一问题还需要对使用流程取得相应证据。

**延伸阅读** 关于经验如何支持一般判断，可以继续阅读 D. Hume 的归纳讨论，以及 J. De Houwer 等人的学习定义研究。T. M. Mitchell 的教材、A. M. Turing 的学习机器讨论与 A. L. Samuel 的跳棋研究，分别补充三要素和早期探索。接下来，第 2章比较规律的表示方式，第 3章比较经验与反馈的组织方式；第 2部分分析有限记录所能支持的保证，第 3部分检查保证与实际要求之间的关系。

第 2 章

# 模型简介

同一批已标注邮件，可以支持几种不同的预测办法。我们可以学习特征权重，也可以逐层执行条件规则，还可以保存旧邮件，在预测时查找相近记录。第1章只选择了第一种形式，并用训练确定其中的参数。本章要进一步说明：这些形式各自保存了什么关系，比较它们时应该考察哪些对象。

两个分类器可能给出相同标签，却采用不同表示。一个保留固定权重，另一个依靠历史实例；一个直接计算得分，另一个还描述类别概率。因此，我们分别考察表示规模、变量的概率语义、关系形式、输出接口，以及损失和学习准则。这五项描述模型及其学习设定的不同方面，其中损失连接任务评价与模型选择，不属于预测函数本身。候选函数集合、概率关系、向量差异与评分规则，分别为这些比较提供数学依据。我们先建立模型族、具体模型与训练的区别，再把分类和聚类放到同一组维度中比较。

## 2.1 什么是模型

在第1章的邮件例子中，输入仍是 $\boldsymbol{x} = (x_1, x_2)^{\mathsf{T}}$，两个分量分别表示促销词次数和链接数。规定加权求和后计算垃圾邮件概率，只确定了一种形式。权重不同，同一输入的概率也可能不同，因此训练前面对的是一组候选关系，训练后才选出实际使用的一项。满足给定形式与约束的候选集合称为**模型族**（model family），记为 $\mathcal{H}$；一个具体模型记为 $h \in \mathcal{H}$。预测任务也常把这个集合称为假设空间。“模型族”还可以用于描述聚类、降维与分布建模的候选对象。

候选范围确定之后，还要填入使模型可计算的信息。邮件分类要确定特征权重，聚类可能要确定中心，数据压缩可能要确定投影方向。它们的对象不同，都在把模型族中的可能形式变成一个具体模型。

在选定表示下，由数据估计并用来确定具体模型的量称为模型参数。回归系数、中心坐标和网络权重都具有这项作用。我们用 $\theta$ 记录这些量，$h_\theta$ 表示相应的具体模型。

为直接对照单个函数与候选集合，我们沿用邮件参数 $\theta = (b, w_1, w_2)^{\top}$，写成

$$h_\theta(\boldsymbol{x}) = \frac{1}{1 + \exp[-(b + w_1 x_1 + w_2 x_2)]}, \qquad \mathcal{H} = \{h_\theta : \theta \in \mathbb{R}^3\}. \tag{2.1}$$

其中，$w_1, w_2$ 是两个特征的权重，$b$ 是在加权和之外加入的偏置。集合 $\mathcal{H}$ 包含所有允许的权重组合所确定的模型；例如，令 $b = -2$、$w_1 = 0.8$、$w_2 = 0.3$，就选出了其中一个具体模型。这些数值是概念示例。换参数仍在同一集合内选择，换成条件分支树则改了候选关系的形式，属于另一模型族。

模型族还没有给出怎样作出选择。学习算法读取数据并调整参数，例如邮件算法根据训练样本更新三个数。更换优化步骤，可以保持同一个候选范围，却得到不同的选择过程或结果。因此，模型族说明可选对象，参数值及其模型说明选定对象，学习算法说明从前者到后者的方法。

网络有几层、聚类设几簇、查询参考几个邻居，也会影响这一过程。这些超参数约束模型族或学习规则，可以预先约定或用验证数据选择。固定网络结构后才知道有哪些连接权重，固定邻居数后才知道每次投票使用几个实例。不过，少量配置不意味着预测只需保留少量信息；近邻方法还要依赖保存的样本。

邮件数据也可以用于分组、压缩或描述特征分布。分组可保存代表中心，压缩可保存低维子空间，分布建模则说明特征怎样共同出现。任务变化后，模型的输出可以从类别变为坐标或分布。比较时仍要追踪三个问题：它用什么表示规律，如何据此处理输入，以及表示中的未知量从哪里获得。

表2.1把这几个问题分开。参数化方式比较候选表示的规模，概率语义比较是否建立分布，关系形式比较变量的联系；输出接口说明返回结果，学习准则说明选择依据。它们可以同时描述一个模型，因而不能当作一组互斥类别，也不能由某一项直接推出其余属性。

| 维度 | 要回答的问题 | 主要观察方向 |
|---|---|---|
| 参数化方式与表示规模 | 模型表示规模是否有固定上限? | 参数化、非参数化及半参数化组合 |
| 概率语义 | 是否为有关变量明确建立概率分布? | 非概率、概率 |
| 关系形式 | 有关变量怎样发生联系? | 线性、非线性 |
| 输出接口 | 使用模型时返回什么? | 组织形式与结果含义 |
| 损失与学习准则 | 怎样评价候选模型? | 逐样本差异、关系与结构、轨迹与长期目标 |

表 2.1　认识模型的五个维度。每个维度回答不同问题，不能由其中一项直接推断其余各项。

以式(2.1)为例，逻辑回归保存三个参数，用线性得分计算类别概率，再按概率与标签的吻合程度选择参数。如果只记录最后的垃圾邮件标签，这些选择就不可见。下面先固定模型需要保留的信息，再逐项比较概率、关系、输出与学习准则，例子也扩展到分组和压缩。

## 2.2 参数化方式与表示规模

假设训练邮件由一百封增为一万封。线性分类器可以继续保存原有权重，近邻方法则可能保存更多邮件，树模型也可能增加分支。信息随数据增长的方式，提供了理解**容量**（capacity）的一个入口：我们考察的是候选模型能表达多丰富的关系。

这里先检查候选表示是否受固定参数维数限制，再说明固定部分与可扩展部分如何组合。判断对象是整个模型族，某次训练结果恰好有限，不能证明所有候选的表示都有同一上限。参数范围与结构也会约束容量，因此参数个数并非完整度量；这些限制怎样影响泛化，将由第2部分分析。

### 2.2.1 参数化模型

先看固定维数的情形。输入表示和配置选定后，若模型族中的每个候选都由预先固定维数的参数向量描述，就称为**参数化模型族**（parametric model family），简称参数化模型。候选参数可限制在 $\mathbb{R}^p$ 的某个范围，$p$ 表示维数。训练样本数 $n$ 增加可以改变参数值，却不自动增加 $p$。

线性回归给出了直接例子。$d$ 维输入需要 $d$ 个权重和一个偏置，参数维数为 $p = d+1$。无论用一百还是一万个样本估计，最终预测仍只需这 $d+1$ 个数。固定层数、宽度和连接方式的网络也一样：参数数量可能很大，但由结构配置规定，不因样本数增加而自动增长。

同样的判断也适用于分组。**K 均值模型**（K-means）以 $k$ 个中心代表群组，按最近中心分配新样本；中心也称为原型。固定 $d$ 和 $k$ 后，需要学习并保存 $kd$ 个坐标。二维数据分成两簇时，只需四个坐标加最近中心规则。新训练记录可以移动中心，但不要求为每个记录再增加一套全局参数。

压缩数据时，**主成分分析**（principal component analysis, PCA）保存均值和少量投影方向，以描述数据的主要变化。固定原始维数和保留方向数后，这些量也有固定表示规模。簇数、保留维数与网络宽度属于配置；应先把配置固定，再判断模型族是否以固定维数的参数表示。

### 2.2.2 非参数化模型

另一种选择是让数据增加时也能补充表示，保留更细的局部关系。**非参数化模型族**（nonparametric model family）允许候选关系超出预先固定的有

限维参数形式。这种命名放宽的是固定维数限制，并没有消除需要确定的数值或需要选择的算法配置。

我们可以直接保存邮件及其标签，每次对新邮件查找最近的 $k$ 封，再按标签投票。这就是**$k$ 近邻**（$k$-nearest neighbors, $k$NN）的分类规则。$k$ 规定一次查询参考多少邻居，属于超参数；它没有规定总共保存多少实例。

例如，固定 $k = 3$ 仍无法单独给出预测。还需要知道实例的位置和标签，两份不同数据通常形成不同规则。标准 kNN 用一百个样本时保存一百组特征与标签，用一万个时保存一万组。一次查询都只让三个邻居投票，但邻居身份由新输入与全部实例之间的关系确定。

随着实例增加，不同位置附近的参考信息也增加，可以形成更细的局部划分。预测依赖实例的位置与标签，而不只依赖 $k$ 这个数，这正是 kNN 的非参数化性质。用验证集选择 $k$ 不会改变这种分工：它改变邻域范围，保存的实例仍给出实际预测依据。

把这个 $k$ 与 K-means 的簇数对照，就能看出配置控制的对象不同。K-means 固定 $k$ 以后，中心数量固定；kNN 固定 $k$ 以后，一次投票人数固定，总实例数仍可增加。图2.1将实例、查询点与中心分别画出，供我们比较这两项限制。

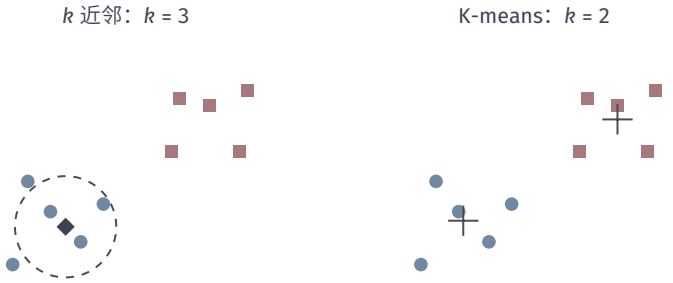


图 2.1　两个 $k$ 控制不同的对象。左侧 kNN 保存十个带标签样本，菱形表示新输入，虚线圈内的三个近邻参加投票；右侧 K-means 用两个中心表示群组。固定近邻数不会固定实例总数，固定簇数则固定了中心数量。图为表示方式的教学示意。

实例预测仍有自己的假设。距离与特征尺度决定邻居身份，$k$ 决定参考范围；改变尺度可能改变结果，增加实例也增加存储和查询成本。这里保存数据是预测规则的组成。线性回归程序也可能为重新训练或来源追踪保留全部数据，但预测函数仍只需固定权重。因此，应看预测关系必须依赖什么，而不能仅数程序保存了多少文件。

数据增加也可以通过条件规则进入表示。**决策树**（decision tree）逐层比较特征阈值，把输入分到区域，再输出区域内的预测。若叶数不设固定上限，更多数据可以支持更多分支，阈值和叶输出的数量也能增长，属于非参

数化设定。若固定深度或叶数上限，表示规模就受到固定限制。第2.4.2节会用平面划分说明这些规则的作用。

**随机森林**（random forest）把多棵树的预测合在一起。仅固定树的棵数，还不足以限定总表示规模；只要各树叶数可以增长，仍可采用非参数化设定。棵数与叶数上限同时固定时，规模才受到相应上限约束。因此，一个配置固定，不等于所有自由度都固定。

局部关系还可以通过加权平均表示。**核回归**（kernel regression）按输入的距离或相似性加权训练目标；控制邻近范围的带宽是超参数，样本位置和目标却随数据补充。即使带宽不变，新增附近成交记录也可能改变房价预测。这种依赖实例的局部平滑属于非参数化方法；近邻、树与平滑的关系可参见统计学习教材[1]。

[1] T. Hastie, R. Tibshirani, J. Friedman, *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*, Springer, 2009, 2nd ed.

### 2.2.3 半参数化模型

房价预测可以对不同输入采用不同限制。假设面积作用采用线性系数，而楼龄关系不预定曲线形式；我们希望保留前一项的固定表示，同时让后一项随数据灵活估计。**半参数化模型**（semiparametric model）就把固定有限维的参数化部分与非参数化部分结合起来。记面积为 $x$、楼龄为 $z$，一个教学设定是

$$f_{\beta,g}(x,z)=\beta x+g(z). \tag{2.2}$$

系数 $\beta$ 描述面积的固定线性作用，未知函数 $g$ 描述楼龄与房价之间的关系，后者可以用局部平滑等非参数化方法估计。学习时既要确定 $\beta$，也要估计整条函数 $g$。命名依据是固定有限维与非参数部分同时存在；参数个数居于两种方法之间，或只有一半参数已知，都不是这里的判断标准。

方法名称也没有唯一决定表示规模。**支持向量机**（support vector machine, SVM）依据得分分类，并在训练时要求样本位于边界的适当一侧、保留一定间隔。间隔的几何意义留到第2.6.2节；这里先比较它采用哪一种表示。

固定 $d$ 维输入的线性 SVM 使用 $s(\boldsymbol{x})=\boldsymbol{w}^{\top}\boldsymbol{x}+b$，预测只需 $d$ 个权重和一个偏置，是固定维数的表示。使用核函数后，还可以用训练样本的贡献写出得分，供我们检查规模如何变化：

$$s(\boldsymbol{x})=\sum_{i\in I_{\mathrm{SV}}} a_i\,\kappa(\boldsymbol{x}_i,\boldsymbol{x})+b. \tag{2.3}$$

其中 $\kappa$ 是用于计算两个输入之间关系的核函数，$a_i$ 为学习得到的系数，$I_{\mathrm{SV}}\subseteq\{1,\dots,n\}$ 包含非零系数对应的训练样本索引，这些样本称为**支持向量**（support vectors）。核函数与特征变换的关系见第2.4.2节。

高斯核 SVM 通常没有等价的固定有限维特征表示，支持向量数又可以随样本增加，因此通常采用非参数化判断。某次模型仅保留部分训练样本，可以降低表示规模，却不把整个模型族改为半参数化。固定带宽等超参数也不固定支持向量数。固定次数的多项式核则对应有限维特征，可以用固定权重表示，需要按具体核重新判断。

半参数化 SVM 要在预测关系中确实保留两种部分，例如用固定系数表示线性趋势，再用非参数化核模型学习修正项，并联合估计两者[2]。这样，固定系数与可扩展修正各有职责。线性、一般核与组合形式的容量不能只凭 SVM 名称推断：应检查特征空间和候选表示。有限的超参数或某次有限的支持向量集合，都不足以代替这项检查。

[2] A. J. Smola, T.-T. Frieß, B. Schölkopf, *Semiparametric Support Vector and Linear Programming Machines* In Advances in Neural Information Processing Systems 11, 1998

## 2.3 变量的概率语义

固定表示规模后，我们仍不知道模型怎样描述结果的不确定性。以明日温度为例，模型可以直接预测 22 °C，也可以描述给定气象观测后温度落在各范围的概率，例如集中在 20 至 24 °C 附近。这里比较的是内部是否建立分布，而非最终只交付点值还是完整分布；分布模型也可以只返回均值。这个区别同样适用于分类、分组与压缩。

### 2.3.1 非概率模型

先考虑直接给温度值的设定。模型用函数、规则或几何关系取得结果，不为当前变量明确建立分布，这称为**非概率模型**（non-probabilistic model）。在温度预测中，记气象特征为 $\boldsymbol{x}$、模型参数为 $\theta$，模型计算

$$\hat{y} = f_\theta(\boldsymbol{x}). \tag{2.4}$$

训练时，根据预测温度与实际温度的偏差调整参数；使用时，将新的观测代入函数，得到一个预测值。例如，输出 22 °C 表示模型给出的温度预测。这个点值仍没有给出偏离程度的概率，更高或更低温度的可能性需要另外说明。

K-means 与 PCA 也能从几何要求直接建立。前者找中心并让样本靠近所属中心，预测时返回最近中心编号；后者找投影方向，利用少量坐标保留主要变化。中心距离和投影已经规定了计算，不需要先给样本假定概率分布。

因此，温度偏差、簇内距离或重构误差可以直接服务于点预测、分组或压缩。若问题扩展为“温度偏离预测超过两度的概率是多少”，上述输出尚未给出答案，需要额外建立概率关系。

### 2.3.2 概率模型

相同观测条件下，明日温度仍可能变化。若要描述这些可能结果，我们把温度视为随机变量，给各范围赋概率。**概率模型**（probabilistic model）就是为任务涉及的随机变量及其关系建立概率分布的模型。对于温度预测，可以让函数给出分布的均值，并用方差描述围绕均值的变化：

$$y \mid \boldsymbol{x} \sim \mathcal{N}\big(\mu_\theta(\boldsymbol{x}), \sigma^2\big). \tag{2.5}$$

这里 $y \mid \boldsymbol{x}$ 表示给定气象特征 $\boldsymbol{x}$ 后的温度，$\mu_\theta(\boldsymbol{x})$ 给出该条件下的均值；$\theta$ 是均值函数的参数，$\sigma^2 > 0$ 是另一个需要从数据中估计的模型参数，完整参数由二者组成。$\mathcal{N}(\mu, \sigma^2)$ 表示均值为 $\mu$、方差为 $\sigma^2$ 的高斯分布。在均值 22 °C、标准差 2 °C 的教学设定中，均值给出中心预测，整个分布还描述偏离它的温度。图2.2对照了这两种预测形式。

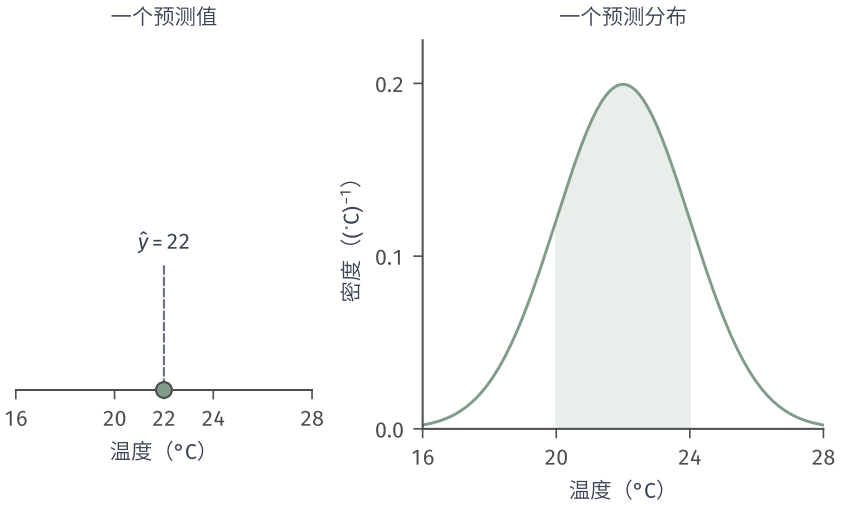


图 2.2 同一温度预测的两种描述。左侧只给出一个预测值；右侧给出高斯预测分布，阴影面积表示温度落在 20 到 24 °C 之间的概率。数值用于教学示意。

固定聚类问题也可以作同样比较。K-means 保存中心并比较距离；**高斯混合模型**（Gaussian mixture model, GMM）用多个高斯分布描述样本，每组还有分散程度和总体比例。处于两组之间的样本，前者按最近中心取得组号，后者可以计算各组归属的后验概率。组的大小、形状与重叠因此都参与判断，不只比较中心位置。

降维中的 PCA 与**概率主成分分析**（probabilistic PCA, PPCA）也共享低维目标，却采用不同描述。PCA 通过线性投影压缩与重构；PPCA 在低维线性表示上加入高斯分布和观测噪声，说明观测怎样分布在子空间附近。在这些假设下，还能估计缺失观测的分布。它增加了观测可能性的描述，而不只是给出投影坐标[3]。

[3] M. E. Tipping, C. M. Bishop, *Probabilistic Principal Component Analysis* In Journal of the Royal Statistical Society: Series B (Statistical Methodology), 1999, vol. 61, no. 3, pp. 611–622

**分类问题的概率建模选择**　给定邮件特征后，类别概率由 $p(y \mid \boldsymbol{x})$ 描述。我们已经用逻辑函数直接建立过这种关系；还可以先描述正常与垃圾邮件各自出现哪些特征，再由特征推测类别。两种路线最终回答相同的分类问题，建立的分布对象却不同，分别称为判别式与生成式建模。

**判别式建模**（discriminative modeling）直接学习输入与类别之间的关系。概率分类时，候选模型描述 $p(y \mid \boldsymbol{x})$，逻辑回归便用带标签样本调整权重，使类别概率与观测标签吻合。模型无须同时描述输入特征的总体分布，或每一类内部的特征分布。更广义的判别式路线还包括只学习得分或决策的 SVM；这里固定概率输出，以便与另一条路线比较。

另一条路线先规定每类有多常见，以及每类内部输入如何分布。用于分类的**生成式建模**（generative modeling）由此建立联合分布 $p(\boldsymbol{x}, y) = p(y)p(\boldsymbol{x} \mid y)$。其中 $p(y)$ 描述各类别的比例，$p(\boldsymbol{x} \mid y)$ 描述每一类内部的特征分布。训练得到这些分布后，再根据新输入的特征反推其类别。对于编号为 $1, \dots, k$ 的类别，由贝叶斯公式得到

$$p(y = c \mid \boldsymbol{x}) = \frac{p(y = c)\, p(\boldsymbol{x} \mid y = c)}{\sum_{j=1}^{k} p(y = j)\, p(\boldsymbol{x} \mid y = j)}. \tag{2.6}$$

公式先用 $c$ 类的比例和输入可能性计算其贡献，再除以所有 $k$ 类的贡献之和。分母必须大于零，归一化所得称为类别后验概率。若只需输出概率最大的类别，比较各类分子即可，因为分母相同。

例如，构造两类邮件比例 $p(y = 1) = 0.2$、$p(y = 0) = 0.8$，标签 1 仍表示垃圾邮件。假设某组计数 $\boldsymbol{x}$ 在两类内部的概率分别为 0.12 与 0.01。类别比例乘以类内概率，得到联合概率 0.024 与 0.008，归一化后垃圾邮件概率为 $0.024/(0.024 + 0.008) = 0.75$。这个教学计算同时利用了输入对类别的区分和总体类别比例。

**朴素贝叶斯**（naive Bayes）按生成式路线估计类内特征分布，增加条件独立假设：给定类别后，各特征相互独立，整组特征的联合条件概率等于各特征条件概率的乘积（可参考第一卷“随机变量”章的“随机变量的独立关系”）。**高斯判别分析**（Gaussian discriminant analysis）也从类内分布出发，但采用多元高斯，能在该模型中保留特征相关性。“生成式”描述的是分布假设的方向：先按 $p(y)$ 取得类别，再按 $p(\boldsymbol{x} \mid y)$ 取得特征。在邮件案例中，这些特征只是计数，能够生成计数并不等于能够生成完整正文；后者需要文本分布。

图2.3把相同的类别后验放到两条计算路线中。判别式直接学习后验，生成式先学习联合分布再计算后验。下方连续曲线进一步显示，条件类别概率随输入变化，而联合密度同时包含特征分布与类别比例；二者的数值所代表的对象不同。

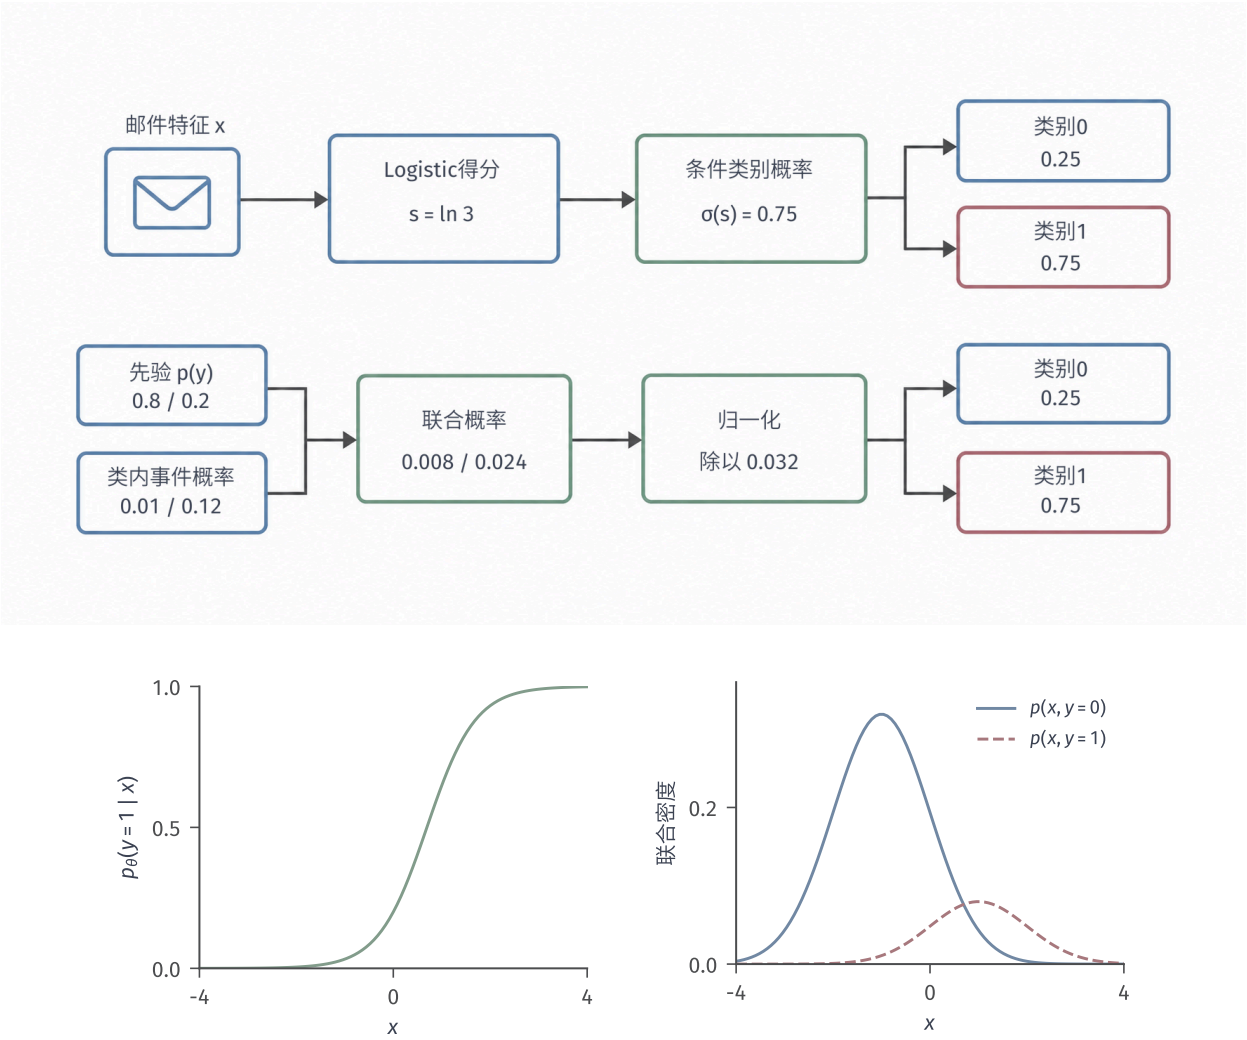


图 2.3 两条分类建模路线。上部框图中的判别式路线以二分类 Logistic 读出为例，令得分 $s = \ln 3$，则 $\sigma(s) = 0.75$，得到类别后验 $p(y = 1 \mid x) = 0.75$、$p(y = 0 \mid x) = 0.25$。生成式路线沿用离散邮件教学数值，先验 0.8、0.2 与类内事件概率 0.01、0.12 相乘，分别得到联合概率 0.008、0.024，再除以总和 0.032。两条路线的数值仅作可核算示意，不假定实际训练结果相同。下方两个面板另用连续构造：先验 0.8、0.2 分别对应 $\mathcal{N}(-1, 1)$、$\mathcal{N}(1, 1)$。左面板为条件类别概率，右面板为先验加权的联合密度，整个实数轴上的两条密度曲线面积分别为 0.8 与 0.2；这些密度值不与上部离散事件概率对应。

训练时也要按所建立的对象评价概率。对独立同分布的带标签样本，判别式负对数似然使用 $p_\theta(y_i \mid \boldsymbol{x}_i)$，生成式则使用 $p_\theta(\boldsymbol{x}_i, y_i)$。即使最后的类别后验具有相同形式，拟合不同概率对象仍可能产生不同参数。前者集中估计类别关系；后者描述范围更广，在假设成立时还能采样或补全，同时也要估计更多关系[4]。

得到类别或区间概率，需要先区分参数已知和参数待估计两种情形。**概率推断**（probabilistic inference）利用模型分布和已有信息计算所需概率。参数给定时，可以直接计算类别概率、区间概率等结果；参数未知时，还要用训练数据确定参数或描述参数的不确定性。

[4] A. Y. Ng, M. I. Jordan, *On Discriminative vs. Generative Classifiers: A Comparison of Logistic Regression and Naive Bayes* In Advances in Neural Information Processing Systems 14, 2001, pp. 841–848

**似然**（likelihood）把观测到的训练数据 $\mathcal{D}$ 固定，比较不同允许参数赋予这些数据的概率或密度。在最大值能够取到时，**最大似然估计**（maximum likelihood estimation）选择使似然最大的参数（可参考第一卷“随机变量”章的“有限维目标的估计”）。一种做法是用**点估计**（point estimation）选出 $\hat{\theta}$，再使用插件预测 $p(y \mid \boldsymbol{x}, \hat{\theta})$；另一种做法是用**贝叶斯推断**（Bayesian inference）结合**先验分布**（prior distribution）与训练数据得到**后验分布**（posterior distribution），再对不同参数对应的预测分布加权平均。

记 $\Theta$ 为参数的允许范围，先考虑参数后验具有相对于 Lebesgue 测度的密度 $p(\theta \mid \mathcal{D})$ 的情形。在新结果 $y$ 给定 $\boldsymbol{x}$ 和 $\theta$ 后与 $\mathcal{D}$ 条件独立的常见设定下，后验预测写为

$$p(y \mid \boldsymbol{x}, \mathcal{D}) = \int_{\Theta} p(y \mid \boldsymbol{x}, \theta) p(\theta \mid \mathcal{D}) \, \mathrm{d}\theta.$$

离散参数将积分换成对允许取值的求和；更一般的后验则按其概率测度积分。插件预测固定一个估计参数，后验预测则对允许参数集合中的预测按后验权重求平均（可参考第一卷“随机变量”章的“预测分布的计算与评价”）。求和或积分传播的是参数不确定性；使用者最终取得点值、摘要或完整分布，还由输出接口决定。即使参数完全给定，模型中的随机结果仍可变化；传播参数后验也不能免除区间覆盖的实际检验。如何检验这些概率输出由第 11章负责；复杂依赖下的推断算法则由 第三卷“模型”的“概率图模型”部分作为**概率图模型**（probabilistic graphical model）专题展开。

上述参数处理方式并没有决定表示规模。成分数固定的 GMM 可以用固定维数参数描述，是参数化概率模型；高斯过程描述一组可能函数上的概率关系，通常属于非参数化概率模型[5]。两个维度仍需分别判断。

[5] C. E. Rasmussen, C. K. I. Williams, *Gaussian Processes for Machine Learning*, MIT Press, 2006

**概率描述带来了什么** 概率信息的用途可以从同一个温度预测看出。两个模型都给出中心值 22 °C，一个集中在 21 至 23 °C，另一个允许更宽的变化。对温度敏感的活动，这两项分布支持不同的风险判断。聚类也一样：GMM 若给某样本近乎相同的两个组别后验，仅取较大者可以作出选择，却没有消除归属的不确定性。

取得分布之后，还需要检验它与未参与训练的结果是否相符。模型给出名义覆盖概率 90% 的区间时，可以统计实际温度进入区间的比例。在同一组独立评价数据上，两个区间的实际覆盖率相近时，较窄的区间一般提供更具体的信息；无限放宽区间虽容易包含真实温度，却未必支持决策。因此，应同时检查预测位置和不确定性范围，不能只看中心误差或只看覆盖。

检验也可能暴露分布形状的限制。例如，同类条件下温度出现两个峰时，单个高斯的均值可能位于二者之间，区间并不能合适地反映观测规律。

错误的群组形状也会影响聚类后验。引入概率只增加了描述不确定性的方式，任务是否获得收益，仍要由假设与数据是否吻合、分布估计是否可靠来决定。

## 2.4 变量的关系形式

相同输入和输出类型，仍然可以采用不同的计算关系。温度可能随某个特征按固定幅度变化，也可能在不同范围按不同规律变化。模型结构描述的就是这项选择。回归可检查预测函数，分类可检查得分或边界，降维可检查坐标映射；判断线性以前，必须先固定正在考察哪一个量。

### 2.4.1 线性结构

先固定其他特征，假设一个特征每增加一单位都带来相同预测增量。线性回归用权重记录这种增量，将 $d$ 维输入 $\boldsymbol{x}$ 与 $\boldsymbol{w} \in \mathbb{R}^d$ 加权相加，再加偏置 $b$：

$$\hat{y} = \boldsymbol{w}^\top \boldsymbol{x} + b = \sum_{j=1}^{d} w_j x_j + b. \tag{2.7}$$

固定其他特征后，$x_j$ 每增加一个单位，预测值都改变 $w_j$。例如，用面积预测房价时，线性关系假设每增加一平方米带来的预测增量相同。严格说，带常数项 $b$ 的关系称为仿射关系；机器学习中通常也将它归入线性模型。

分类概率不能直接使用任意实数得分。逻辑回归通过转换函数把得分放到零与一之间。记二分类正类概率为 $p$，计算及其等价变形为

$$p = \frac{1}{1 + \exp[-(\boldsymbol{w}^\top \boldsymbol{x} + b)]}, \qquad \log \frac{p}{1-p} = \boldsymbol{w}^\top \boldsymbol{x} + b. \tag{2.8}$$

左式将任意实数得分转为零与一之间的概率。右式来自对左式的变形：$p/(1-p)$ 比较正类与负类的概率大小，再取对数，就得到**对数几率**（log odds）。这个量仍然是输入的仿射函数。用 $p = 0.5$ 作分类阈值时，两类概率相等，对数几率为零，边界因而满足 $\boldsymbol{w}^\top \boldsymbol{x} + b = 0$。当 $\boldsymbol{w} \neq \boldsymbol{0}$ 时，这个方程在二维平面中给出一条直线；若 $\boldsymbol{w} = \boldsymbol{0}$，概率不随输入变化，就不存在这样的直线分界。所以这里把逻辑回归称为线性分类模型时，指的是对数几率或分界关系，概率本身仍经过非线性转换。

逻辑回归的线性指对数几率和分类边界，线性回归的线性则指预测值。基础**感知机**（perceptron）也计算加权得分，再按正负分类。感知机与线性 SVM 学习参数的准则不同，却都用线性分界面完成二分类，因此关系形式不能替代训练准则的比较。

PCA 也使用线性关系，只是对象改为投影坐标。均值与方向固定后，每个坐标都是中心化输入的加权和。PPCA 加入分布与噪声假设，仍保留低

维表示到观测均值的线性关系。因此，这项结构选择可以用于预测、分类、降维和概率建模，并不专属某一个任务。

K-means 没有预先给类别边界，但最近中心规则会产生分配区域。为找出两个区域之间的分界，取中心 $\boldsymbol{\mu}_1$ 与 $\boldsymbol{\mu}_2$，边界上的样本满足 $\|\boldsymbol{x}-\boldsymbol{\mu}_1\|_2^2 = \|\boldsymbol{x}-\boldsymbol{\mu}_2\|_2^2$。展开两边并消去共同的 $\boldsymbol{x}^\top\boldsymbol{x}$ 项，得到

$$2(\boldsymbol{\mu}_2-\boldsymbol{\mu}_1)^\top\boldsymbol{x} = \|\boldsymbol{\mu}_2\|_2^2 - \|\boldsymbol{\mu}_1\|_2^2. \tag{2.9}$$

消去平方项后得到输入的仿射方程，说明两个不同中心之间的分配边界是线性的。距离本身仍是二次函数，输出的离散编号也不能解释为输入的线性函数。后文将 K-means 放在线性一侧时，专指这种两两分配边界。

输入表示改变后，线性判断也可能改变。先把 $x$ 变成 $x^2$，再计算 $wx^2+b$，对新特征是线性的，对原始 $x$ 却不是。本章主要以原始输入为基准。参数的线性出现方式也属于另一个观察对象，不能与预测对输入的线性混为一谈。

### 2.4.2 非线性结构

固定增量假设未必适合当前对象。速度增加时，刹车距离通常不按同一增量改变；剂量作用可能随区间改变；促销词的含义还可能依赖外部链接数。我们要表达的于是包括弯曲、阈值和特征共同作用，单个仿射关系未必充分。

保持上一节的观察对象，如果预测值或得分不能写成原始输入的仿射函数，就称这一关系为非线性。二分类若需要弯曲或分段边界，也不能只用一个超平面。图2.4固定同一组中心与外圈样本作比较：任何直线都无法完全分开两类，径向边界却可以。差别来自候选关系，而不是更换了评价样本。

曲线能弯曲，并没有同时规定其他维度。固定次数的多项式回归只需固定系数，是参数化的非线性模型；高斯过程同样能产生弯曲关系，却对函数建立概率分布，并不受固定有限维系数限制。因此，图形只显示关系形式，表示规模和概率语义仍需另外考察。

多个特征也可以共同决定变化。关系中出现 $x_1x_2$ 时，改变 $x_1$ 的作用会随 $x_2$ 而变，称为特征交互。例如，可以规定只有邮件带有外部链接时，新增促销词才提高怀疑得分；不带链接时，促销词的权重为零。两个计数的固定权重和无法令同一项的权重随另一项改变。分别观察每个特征可能看不到这一点，需要把它们放到共同关系中比较。

是否扩大表示，需要任务数据提供依据。线性关系给出了固定特征增量的基线；若独立验证样本显示，模型在某些输入范围持续高估、在另一些范围持续低估，或误判集中于特定特征组合，就需要检查固定增量假设是

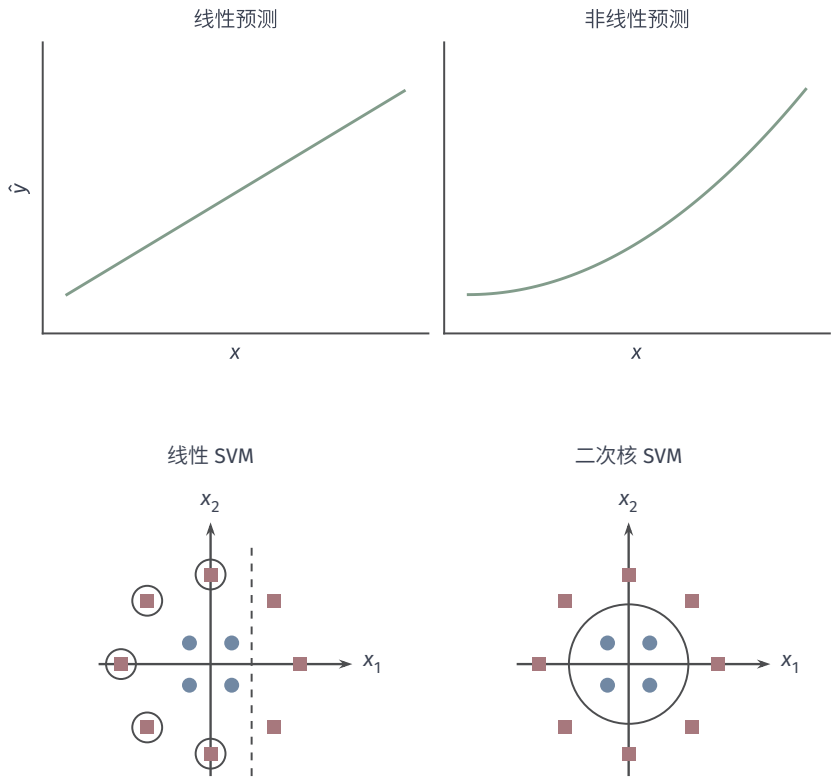


图 2.4 线性与非线性关系的几何示意。上排依次为线性预测与非线性预测，下排用同一组环形样本对照线性 SVM 的限制与二次核 SVM 的表达能力；圆点和方点代表两类。左图虚线只展示一条候选直线，空心圈标出按其左右类别分配时的错分方点，不代表最优 SVM 解。外圈方点的凸包包含内圈圆点，故任何直线都不能完全分离这组样本。右图以圆心为坐标原点，半径 8 的边界可由二次核 $\kappa(\boldsymbol{u},\boldsymbol{v})=(\boldsymbol{u}^{\top}\boldsymbol{v})^2$ 与偏置表示。图为几何构造，非训练结果。

否遗漏了弯曲、阈值或交互关系。增加分段规则或非线性变换，是针对这些具体偏差扩展候选表示，效果仍需验证。表达范围扩大，也更容易迎合偶然波动，需要配合数据量和结构限制判断。下面比较按条件划区与改变特征这两种实现方式。

**按条件采用不同规则** 我们可以先确定输入落在哪个区域，再按区域使用规则。决策树把这一步写成连续条件判断，例如促销词达到阈值后再检查链接数。根到叶的路径汇集了输入要满足的条件，叶节点给出对应区域的预测。图2.5把相同条件同时画成判断树和平面区域，以便直接对照。

单个特征阈值只划分两侧，多次组合却能形成复杂区域。常见树在叶节点给固定输出，跨过区域边界时预测可能跳变。这种结构适合表达条件规则，但表示规模还取决于叶数：允许随数据增长是非参数化设定，固定上限则限制候选规模。非线性的分支结构与参数化方式因此需要分开判断。

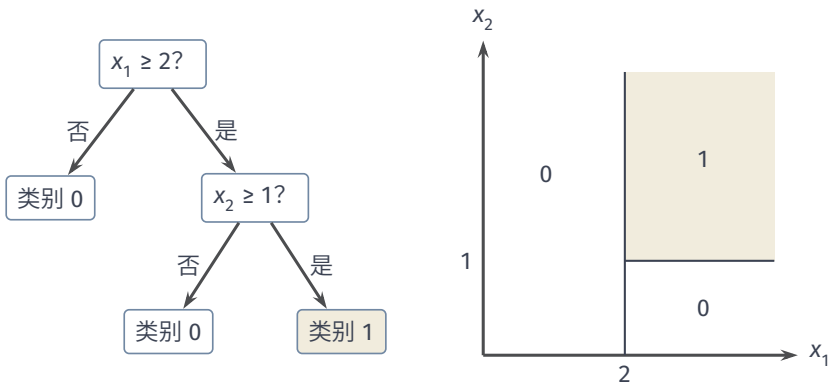


图 2.5 按条件分情况处理输入。左侧为判断树，右侧为对应的输入区域。该教学例子在 $x_1 \geq 2$ 且 $x_2 \geq 1$ 时输出类别 1，其余区域输出 0。

**对输入进行非线性变换** 另一种方式先保留能表达变化的特征，再计算得分。平方项 $x_1^2$ 可以表示弯曲，乘积 $x_1 x_2$ 可以表示交互。把变换记为 $\boldsymbol{\phi}(\boldsymbol{x})$，在新特征上使用线性得分：

$$s(\boldsymbol{x}) = \boldsymbol{w}^\top \boldsymbol{\phi}(\boldsymbol{x}) + b. \tag{2.10}$$

变换中的非线性关系可能使这个线性得分在原空间形成非线性边界。例如，中心区域是一类、外围是一类时，可以把到原点的平方距离 $x_1^2 + x_2^2$ 作为新特征，再用一个阈值区分两类。

**核方法**（kernel methods）借助特征空间内积使用变换后的关系，无须逐一写出所有特征。线性核仍对应线性关系，高斯等非线性核可以形成弯曲边界。标准高斯核 SVM 可以随样本保留更多系数，采用非参数化表示；若先固定有限个变换特征作近似，就改变了候选规模的设定[6]。

手工加入平方项和交互项，仍需要预先选择变换。神经网络让中间变换也由训练确定：多层网络在加权和之间加入**激活函数**（activation function），例如把负值置零、保留非负值，使不同输入范围有不同计算关系。训练目标共同调整这些中间表示和最终预测。如果各层都只有加权和与偏置，把一层代入下一层仍得到仿射函数；单纯堆叠这样的层，并不会扩大到非线性关系。

树按条件改变规则，特征变换则让新的坐标表达弯曲与交互。两种思路可以交叉，分段线性网络也能形成不同计算区域。无论采用哪一种，结构只说明可表达什么，新样本上的效果还要由数据、限制与训练方式支持。

计算图和概率图都用节点与边组织变量，但读图时要依据各自的语义。神经网络中的边规定一个数值怎样进入后续计算；概率图中的边参与规定局部概率分解，而条件独立关系要按照该类图的判定规则读取。边的存在允许直接联系，缺边所表达的独立性则依赖图的语义及模型假设。这两种

[6] C. Cortes, V. Vapnik, *Support-Vector Networks* In Machine Learning, 1995, vol. 20, no. 3, pp. 273–297

组织方式可以结合：用神经网络计算某个分布的参数，既保留非线性计算，又建立概率描述。

## 2.5 输出的形式与含义

设定了模型内部的计算关系以后，我们还要决定把哪些结果交给使用者。温度预测可以只返回一个数，也可以提供预测区间或完整分布；邮件分类可以直接返回类别，也可以同时列出类别概率。因此，说明输出需要分两步：先说明结果按标量、向量还是位置与顺序构成的对象组织，再说明其中数值代表预测值、类别编码、分布摘要、完整分布还是采样结果。只给出形状，使用者仍不知道这些数怎样用于判断。

### 2.5.1 输出的组织形式

**标量输出** 温度预测若只返回 22 °C，结果便由一个数及其单位构成。价格预测和商品评分也常采用这种**标量输出**（scalar output）。使用时，数值必须连同单位或评分尺度一起解释。

一个数也可以用作编号。邮件分类中的 0 与 1 可分别表示正常邮件和垃圾邮件，聚类中的 $1, 2, \dots, k$ 则区分发现的群组。前者的含义由预先定义的标签确定，后者的含义来自分组结果。交换簇编号不会改变哪些样本同属一组，因而编号之差通常不能解释为距离。

**向量与结构化输出** 同时预测温度、湿度和风速时，单个数已经容纳不了全部结果，我们需要按约定次序返回三个分量。这便是**向量输出**（vector output）。未来七天的温度也可以组成向量，不过此时分量依次对应日期。使用任何这样的结果，都要知道各坐标对应的对象、单位和顺序。

向量还可以描述输入，而不直接给出任务答案。PCA 的输出坐标记录样本沿各投影方向的位置，神经网络也可以把图像映射成用于检索或分类的特征向量。同一图像经过裁剪、颜色变换等处理得到的输入版本称为**视图**（view）。若这些变换按任务设定保留内容含义，训练便可以要求不同视图的表示在指定距离或相似度下接近；这里需要保留的是表示之间的关系。

重构图像时，输出虽也是一组数值，却必须按像素位置和颜色通道还原成数组。文本则要保留符号顺序，还可能具有不同长度。对于这些结构化结果，分量值与位置、顺序或连接关系共同决定含义，不能任意交换坐标。

组织形式确定以后，输出含义仍需单独说明。三个数可以是三个温度预测，也可以是三个类别的概率；后一种解释额外要求分量非负且总和为一。一个数也可能是测量值或类别编号。下面我们据此区分直接结果、分布摘要和概率分布，说明同样形状的接口可以提供哪些不同信息。

### 2.5.2 输出的含义

第2.3节判断模型是否为变量建立分布。这里转而查看使用者实际收到什么：模型可能交付完整分布，也可能只返回由它计算的类别、均值或区间。模型内部保留的信息与接口交付的信息应分别说明。

**点结果与分布摘要** 直接结果可以是一个预测值、类别或簇编号。即使内部建立了概率分布，接口也可以只返回摘要：逻辑回归选出概率最大的类别，高斯温度模型报告均值或预测区间。摘要使比较与决策更方便，却省略了部分可能结果及其概率。因此，输出一个点或区间，并不能据此判断模型内部有无概率语义。

**概率分布与采样** 若使用者需要比较各个结果的可能性，接口就应保留**概率分布输出**（probability distribution output）。有限类别可以逐项列出非负且总和为一的概率。例如，邮件分类的 $(0.2, 0.8)^\top$ 分别给正常邮件和垃圾邮件赋予 0.2 与 0.8。它比单个类别标签多保留了概率如何分配的信息。不过，这些数能否对应实际频率，还要通过校准检验，不能仅凭概率集中就宣称预测可靠。

连续结果通常无法逐个列出概率，而是通过分布形式及其参数说明。例如，指定高斯分布并给出均值 22、方差 4，就确定了温度的密度曲线。某一区间对应的曲线下面积才是落入该区间的概率；单点的曲线高度是密度，不能当作恰好取该值的概率。

一个概率模型由此可以提供三种接口：交付分布、计算摘要，或从分布采样。温度模型可以报告均值 22 °C，也可以给出包含指定模型概率质量的预测区间；后者的名义概率水平是否达到实际频率覆盖，需要另用未参与训练的数据检查。一次采样则可能返回 21.3 °C。图像生成也遵循这个区别：分布描述可能图像，采样才产生一张具体图像，多次采样可以产生不同结果。

因此，输出形状与输出含义要配合解释。类别分布可以写成向量，分布均值可以是标量，采样结果可以是高维数组。明确返回几个分量以后，我们还要交代它们是直接答案、分布的概括、完整概率描述，还是一次实现结果。

## 2.6 损失与学习准则

模型能够表示和输出一个结果，接下来需要说明它怎样借助数据作出选择。邮件分类和聚类都可返回编号，但分类已有正确标签，可以比较预测与答案；聚类没有逐样本标签，需要从样本之间的关系规定分组依据。对

于要拟合的模型，我们必须给出评价候选结果的准则；对于没有显式参数拟合目标的方法，则要说明实际形成输出的规则。

本节从评价所用的信息展开。逐样本答案已知时，我们比较数值、向量或概率分布与目标的差异；答案缺失或任务还关心对象之间的关系时，我们规定紧凑性、分类间隔、相对邻近或低维结构；行动会改变后续结果时，评价需要延伸到轨迹和长期收益。这些准则可以组合，例如 PCA 在低维限制下减小重构误差。没有显式拟合目标的方法应标明这一情况，不能把保存或查询步骤写成损失。

### 2.6.1 逐样本的目标差异

先看每个样本都有答案的任务。温度、价格与销量预测有待预测的真实数值，分类有真实类别，但两类答案所需的比较方式不同。记第 $i$ 个样本的答案为 $y_i$、预测为 $\hat{y}_i$，我们通常先计算单个样本的损失，再在 $n$ 个样本上求平均，以评价模型整体表现。

**连续数值** 预测高于真实温度两度与低于真实温度两度，都偏离两个单位。直接累加带符号误差会使二者抵消，我们可以改用平方或绝对值计算损失：

$$\ell_{\mathrm{sq}}(\hat{y}, y) = (\hat{y} - y)^2, \qquad \ell_{\mathrm{abs}}(\hat{y}, y) = |\hat{y} - y|.$$

在样本上求平均，分别得到第 1.5节的均方误差与平均绝对误差。真实值为 20、预测为 22 时，单个平方误差为 4，绝对误差为 2；偏差从 2 增至 4 时，二者分别增至四倍和两倍。因此，平方误差更强调大偏差，作为预测值的函数也处处可导；绝对误差对个别大偏差的影响较小，但在零误差处不可导，优化需作相应处理。

误差的两个方向还可能具有不同代价。备货不足会造成缺货，备货过多会增加库存成本，二者未必应受相同惩罚。此时损失要分别反映高估和低估的后果，而不只是笼统要求数值接近。

**离散类别** 类别编号表示身份，而非连续尺度。若 1、2、3 分别代表猫、狗、鸟，编号之差无法评价误判严重程度。**零一损失**（zero-one loss）因此只检查预测与真实类别是否相同：

$$\ell_{01}(\hat{y}, y) = \begin{cases} 0, & \hat{y} = y, \\ 1, & \hat{y} \neq y. \end{cases} \tag{2.11}$$

其样本平均即分类错误率。但只要预测类别不变，参数怎样微调都不会改变这个损失，它难以指引连续参数更新。训练时常采用随得分或概率变化的**代理损失**（surrogate loss），如后文的类别交叉熵和第2.6.2节的间隔损

失，以便优化。若误判类型的代价不同，还可以用预先给定的代价表替代统一的 1。

**向量的差异** 图像去噪要比较输出图像与干净图像，重构要比较恢复结果与原输入，多变量预测则要同时比较多个观测量；它们的答案都是向量。表示学习也比较向量，例如让同一图像的不同视图在指定度量下接近。前一类任务常关心每个分量能否恢复，后一类可能主要关心整体方向或相对位置，因此不能只凭向量形式选定损失。

设预测为 $\hat{\boldsymbol{y}}$，目标为 $\boldsymbol{y} \in \mathbb{R}^m$。逐分量比较可采用

$$\ell_2(\hat{\boldsymbol{y}}, \boldsymbol{y}) = \|\hat{\boldsymbol{y}} - \boldsymbol{y}\|_2^2 = \sum_{j=1}^{m} (\hat{y}_j - y_j)^2, \tag{2.12}$$

$$\ell_1(\hat{\boldsymbol{y}}, \boldsymbol{y}) = \|\hat{\boldsymbol{y}} - \boldsymbol{y}\|_1 = \sum_{j=1}^{m} |\hat{y}_j - y_j|. \tag{2.13}$$

第一式累加平方偏差，大误差获得较高权重；第二式累加绝对偏差，个别异常分量的影响较小。两者都受坐标尺度影响，同时比较温度与气压时，就需要决定是否缩放分量或设置权重。

若关心向量方向而非长度，我们可以比较夹角的**余弦相似度**（cosine similarity），方向越接近，相似度越大。对非零向量 $\boldsymbol{a}$、$\boldsymbol{b}$，将它转为要最小化的损失可写成

$$\ell_{\cos}(\boldsymbol{a}, \boldsymbol{b}) = 1 - \frac{\boldsymbol{a}^\top \boldsymbol{b}}{\|\boldsymbol{a}\|_2 \|\boldsymbol{b}\|_2}. \tag{2.14}$$

$(1,2)^\top$ 与 $(2,4)^\top$ 虽长度不同，但同向，因而余弦损失为零，欧氏误差却非零，见图2.6。这种忽略长度变化的比较可用于某些文档或图像表示；若幅度本身代表温度、亮度或数量，它也会漏掉任务所需的信息。

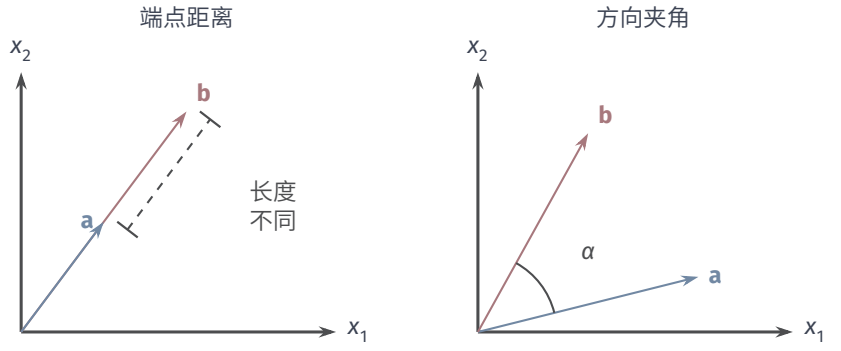


图 2.6 两种向量比较方式关注不同差异。左侧比较两个端点之间的距离，右侧比较向量方向之间的夹角。同向但长度不同的向量，余弦损失为零，欧氏误差仍大于零。

数值误差是否符合任务中的相似性，还取决于所用表示。一张图像只平移一个像素，内容可能基本相同，许多对应像素却已有较大差异。位置必须精确对应的重构适合逐像素比较；关心物体内容的任务则可能先提取特征，再比较表示。选择度量时，我们也在选择要保留哪些差别。

**概率分布的差异** 概率输出包含的信息多于最终类别或均值。邮件分类可能还要求概率能够用于风险判断，分布学习要描述样本出现的规律，模型模仿则可能要求两个模型对各类别给出相近概率。面对这些任务，只比较选出的答案会漏掉其余概率信息，我们需要评价分布本身。

有限类别的概率分布可以逐项比较。设目标 $\boldsymbol{p} = (p_1, \dots, p_k)^{\top}$、预测 $\boldsymbol{q} = (q_1, \dots, q_k)^{\top}$ 均非负且各自求和为一。模型给结果 $j$ 的概率越低，$-\log q_j$ 越大；以目标概率 $p_j$ 加权平均，便得到**交叉熵**（cross-entropy）：

$$\mathrm{CE}(\boldsymbol{p}, \boldsymbol{q}) = -\sum_{j=1}^{k} p_j \log q_j. \tag{2.15}$$

其中 $p_j = 0$ 的项约定为零，$p_j > 0$ 而 $q_j = 0$ 时取无穷大。已知样本类别为 $c$ 时，可以把目标写成 $p_c = 1$、其余为零的**独热表示**（one-hot representation），损失于是化为 $-\log q_c$。给正确类别 0.9 比 0.1 产生的损失小，而 $q_c$ 趋近零时损失趋向无穷大，故自信的错误受到较重惩罚。本节使用自然对数（可参考第一卷“概率分布”章的“对数评分的差异”和第一卷“随机变量”章的“预测分布的计算与评价”）。

预测分布与目标分布相同，交叉熵仍可能为正，因为目标本身可能有不确定性。若要把完全相同的分布记为零差异，就需从交叉熵中扣除目标分布对自身的交叉熵。

扣除目标自身的交叉熵，得到**KL 散度**（Kullback–Leibler divergence）：

$$D_{\mathrm{KL}}(\boldsymbol{p} \| \boldsymbol{q}) = \sum_{j=1}^{k} p_j \log \frac{p_j}{q_j}. \tag{2.16}$$

KL 散度也沿用前面的零质量与零预测概率约定。散度非负，且仅在两个分布相同时为零。把式(2.16)中的对数比值拆开，可得 $D_{\mathrm{KL}}(\boldsymbol{p} \| \boldsymbol{q}) = \mathrm{CE}(\boldsymbol{p}, \boldsymbol{q}) - \mathrm{CE}(\boldsymbol{p}, \boldsymbol{p})$；目标固定时，后一项不随预测改变，因此两种准则的最小化要求相同。交换目标与预测会改变加权所依据的分布，KL 散度一般也会改变。

也可以把预测概率与观测类别的独热向量直接比较。类别为 $c$ 时，$\boldsymbol{e}_c$ 仅第 $c$ 项为 1，**Brier 评分**（Brier score）写为

$$\ell_{\mathrm{Brier}}(\boldsymbol{q}, c) = \sum_{j=1}^{k} (q_j - \mathbb{I}\{j = c\})^2. \tag{2.17}$$

按这个求和定义，评分在 0 到 2 之间。二分类若只用正类概率 $q \in [0,1]$ 和标签 $y \in \{0,1\}$ 计分，常写为 $(q-y)^2$；上式同时计算两个类别的偏差，等于这个单项评分的两倍。真实类别分布为 $\boldsymbol{p}$ 时，其期望可分成不依赖 $\boldsymbol{q}$ 的不可约项与 $\|\boldsymbol{q}-\boldsymbol{p}\|_2^2$，所以 $\boldsymbol{q}=\boldsymbol{p}$ 取得最小值。它对极端错误的惩罚有上限，交叉熵则没有，两者由此赋予少数自信错误不同权重。Brier 评分既可训练也可评价概率预测，是较早提出的概率预报准则之一[7]。

[7] G. W. Brier, *Verification of Forecasts Expressed in Terms of Probability* In Monthly Weather Review, 1950, vol. 78, no. 1, pp. 1–3

学习数据分布时，我们通常只掌握样本，并不知道真实分布。对模型密度 $p_\theta(\boldsymbol{x})$，可以最小化平均负对数似然：

$$\ell_{\mathrm{NLL}}(\theta) = -\frac{1}{n}\sum_{i=1}^{n} \log p_\theta(\boldsymbol{x}_i). \tag{2.18}$$

它鼓励模型对已观测样本给出较大的概率或密度，GMM 等分布模型可以使用这一目标。若真实分布 $P$ 和模型 $Q_\theta$ 相对共同参考测度有密度，且 $P \ll Q_\theta$、真实密度的对数在 $P$ 下可积、模型负对数密度的期望有定义，总体期望负对数似然就是交叉熵；固定 $P$ 后，最小化它等价于在模型类内减小 $D_{\mathrm{KL}}(P\|Q_\theta)$。模型失配时，即使求得类内最优解，它也只能近似真实分布；有限样本的经验优化还需一致收敛或估计条件，不能只凭独立同分布抽样推出总体最优。若 $y$ 是有限类别标签，拟合 $p_\theta(y \mid \boldsymbol{x})$ 时，相应负对数似然就是分类交叉熵。

目标固定时，交叉熵与 KL 散度的最小化要求相同；Brier 评分则限制了极端错误所受的惩罚。这些准则依据各结果的概率进行比较，并不自动知道两个类别或位置相距多远。若任务关心概率质量移动的距离，还需要把结果空间中的距离纳入准则。

### 2.6.2 关系与结构准则

没有逐样本答案时，我们可以规定对象应当怎样组织；已有答案时，任务也可能在逐样本正确之外提出关系要求。聚类要求同组样本紧凑，检索要求相关样本更近，分类可以要求正确一侧的样本还离边界足够远，降维则限制表示所在空间的维数。这些关系与结构准则比较的对象各不相同；其中有些是必须满足的约束，有些是通过损失鼓励的性质。

**样本到中心的距离** K-means 选择 $k$ 个中心，让每个样本与最近中心的平方距离尽量小：

$$\min_{\boldsymbol{\mu}_1,\dots,\boldsymbol{\mu}_k} \frac{1}{n}\sum_{i=1}^{n} \min_{1\le j\le k} \|\boldsymbol{x}_i-\boldsymbol{\mu}_j\|_2^2. \tag{2.19}$$

内层在固定中心下为样本选择归属，外层改变中心位置以缩小平均距离。簇编号来自这一几何准则，没有真实类别作参照。平方距离提高远点的影响，偏好围绕中心的紧凑群组。若换成 $L_1$ 距离，固定分组后的最优中心

为各坐标中位数，对少数远点通常更稳健；若方向更重要，则可另选基于余弦相似度的准则。

K-means 的目标只直接缩小簇内平方距离，并未要求每两个簇都尽量远离。中心取各簇均值时，总平方离差可以分为簇内项与簇间项；固定数据后，前者减小会使后者增大。不过，簇间项衡量各中心相对总体均值的分散程度，不能保证所有簇对都充分分离。

**样本到分类边界的间隔** SVM 在预测正确之外还要求留出**间隔**（margin）：样本应位于边界正确一侧，并与边界保持余量。令 $y \in \{-1, +1\}$，得分 $f(\boldsymbol{x}) = \boldsymbol{w}^{\top}\boldsymbol{x} + b$，常用**合页损失**（hinge loss）为

$$\ell_{\text{hinge}}(y, f(\boldsymbol{x})) = \max\{0, 1 - y f(\boldsymbol{x})\}. \tag{2.20}$$

得分满足 $y f(\boldsymbol{x}) \geq 1$ 时损失为零，错误分类或余量不足则受到惩罚。不过，单纯放大得分就可能降低该损失，而边界位置未变。线性 SVM 还惩罚 $\|\boldsymbol{w}\|_2^2$：当 $\boldsymbol{w} \neq \boldsymbol{0}$ 时，有符号几何距离为 $y f(\boldsymbol{x})/\|\boldsymbol{w}\|_2$；固定得分余量为 1，较小权重范数对应较大几何间隔。损失与惩罚共同权衡余量违反及间隔大小，无需把全部同类样本压到一个中心附近。

**相关样本之间的相对距离** 检索有时只需要保留相对次序：同一物体的两张照片应比不同物体的照片更近。令参照表示为 $\boldsymbol{a}$、相关表示为 $\boldsymbol{p}$、不相关表示为 $\boldsymbol{n}$，指定距离 $d$ 及余量 $m > 0$，**三元组损失**（triplet loss）比较两段距离：

$$\ell_{\text{triplet}} = \max\{0, d(\boldsymbol{a}, \boldsymbol{p}) - d(\boldsymbol{a}, \boldsymbol{n}) + m\}. \tag{2.21}$$

相关样本至少近 $m$ 时，损失为零，否则不足的差额计入损失。它规定相对关系，不要求表示围绕固定中心。效果依赖距离、样本配对和余量：容易满足的比较少有学习信号，错误配对会促成错误邻近关系。图2.7对照中心距离、分类间隔与相对距离；依据已知相似关系学习表示或距离，是**度量学习**（metric learning）的基本思路[8]。

PCA 提供另一种组织要求：先把表示限制在低维空间，再减小重构误差。将它与上述例子对照，中心距离要保留紧凑群组，分类间隔要保留边界余量，相对距离要保留邻近次序，低维约束要压缩表示。选用哪一种，取决于任务需要保留什么；一个模型也可以同时满足几种要求。

[8] K. Q. Weinberger, L. K. Saul, *Distance Metric Learning for Large Margin Nearest Neighbor Classification* In Journal of Machine Learning Research, 2009, vol. 10, no. 9, pp. 207–244

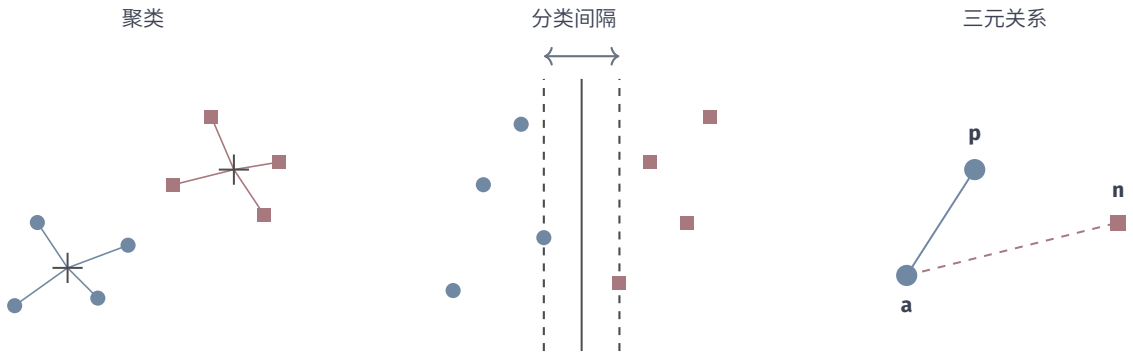


图 2.7 三种几何要求。左侧缩短样本到所属中心的距离；中间让带标签样本与分类边界保持间隔；右侧要求相关样本比不相关样本更接近参照样本。三者分别比较不同的几何对象。

### 2.6.3 轨迹与长期目标

机器人导航中的一步不能只按眼前离终点有多近评价：看似向前的动作可能进入死路，暂时绕行却可能更早到达。游戏决策和连续资源调度也会由当前动作改变后续状态与奖励。我们因而需要评价整段行动，并考虑环境与动作选择可能产生的不同经历。

动作规则与环境共同决定一条轨迹。常见评价先累计轨迹中的多步奖励，再对可能轨迹取期望；另一些任务比较长期运行的单位时间平均回报。两种选择对后果的重视方式不同，都无法由单步即时误差代替。第 3.3节会先定义状态、动作、奖励和策略，再写出这些目标。

期望回报还不能说明结果是否稳定。若失败概率也受到限制，目标之外就需加入相应约束；若轨迹很长或关键事件罕见，有限次交互对长期表现的估计也可能波动较大。

整段决策的目标可以包含局部预测损失。例如，价值模型预测未来累计回报，训练时可以使用平方误差，这个预测任务服务于决策。反过来，输出是序列也不意味着评价整段行动：逐词预测文本可以在每个位置比较类别概率，其学习准则仍是概率分布拟合。

损失与回报规定怎样比较结果，梯度下降和交替更新等算法则规定怎样寻找更好的结果，二者需要分别说明。准则还可能只用于局部选择：决策树每一步评价候选分裂，未必优化整棵树的单一全局目标；近邻分类没有参数拟合目标，而是在查询时按距离选择 $k$ 个已保存样本并投票。因此，列出准则以后，还要交代它作用于整个模型、某个步骤，还是对当前方法不适用。

## 2.7 模型维度的交叉与组合

一个非线性模型可以具有固定数量的参数，一个概率模型可以只返回一个数。前文反复出现这些交叉，是因为五个维度要分别判断。下面把它们放回同一任务，查看改变某项设定会影响哪些选择、保留哪些性质。

### 2.7.1 模型维度的组合

以气象特征预测明日温度，先固定输入表示。我们可以选用固定数量的权重计算仿射函数，返回一个温度值，再以平方误差拟合数据。这个具体方案采用参数化表示、非概率语义和线性关系，接口返回标量，学习准则比较预测温度与观测值。任务名称只说明要预测什么，这些属性都由方案的具体设定确定。

若仍用仿射函数计算均值，却同时估计方差并指定高斯分布，固定维参数化方式得以保留，表示规模则因方差参数而增加。均值的关系形式也保留，但模型开始描述温度分布，训练准则相应转为评价观测数据的似然。

我们还可以保留点预测接口，改用含非线性激活的固定结构神经网络：参数化方式不变，关系形式改变；若让它计算分布参数，便又加入概率语义。近邻回归依赖随数据增加的实例，构成非参数化、非概率方案；高斯过程不受固定有限维系数限制，同时为可能函数与预测结果建立分布。这些例子说明，同一任务并不固定五个维度的取值。

各项设定也不能任意拼接。标量温度可用平方或绝对误差比较，类别概率可用交叉熵或 Brier 评分评价；类别编号只是身份，编号相减不能直接表示误判代价。若模型同时报告方差，均值误差还会漏掉它提供的部分信息。输出所含的信息应在评价中得到对应解释。

表示限制同样会进入准则：K-means 用有限中心描述群组，并缩小样本到中心的距离；PCA 限制低维子空间，再评价重构误差。五维分析由此帮助我们检查表示规模、概率语义、关系形式、输出和评价依据能否共同完成任务。

### 2.7.2 分类模型的五维比较

现在用分类检验这套描述。章首的权重、规则树和近邻都能预测类别，它们在哪些方面相近，又在哪些方面不同？表2.2给出九个具体版本。沿列阅读可比较同一属性，沿行阅读则可检查一个模型的全部设定。

阅读表格前，需要限定其中几种版本。高斯判别分析以类内高斯分布计算后验，**协方差**（covariance）描述各方向的分散程度及相关性；各类共用同一非奇异协方差矩阵时，对数后验之差是线性的，各类分别使用不同协方差时一般形成二次边界，称为**二次判别分析**（quadratic discriminant

analysis）。朴素贝叶斯取伯努利版本，以 0、1 记录词是否出现；当各类内特征概率严格位于零与一之间时，类别对数几率可写成二值特征的线性函数。神经分类器先对各类别得分取指数，再除以这些指数值的总和，得到非负且总和为一的类别概率，并以分类交叉熵训练。硬标签决策树逐步选择加权基尼不纯度下降最大的有效分裂；节点不纯度为 $1-\sum_c \hat{p}_c^2$，其中 $\hat{p}_c$ 是该节点的类别样本比例。

| 具体模型设定 | 参数化方式与表示规模 | 概率语义 | 关系形式 | 输出接口 | 损失与学习准则 |
|---|---|---|---|---|---|
| 线性 SVM | 参数化 | 非概率 | 线性得分 | 得分、类别 | 合页损失与权重惩罚 |
| 逻辑回归 | 参数化 | 概率 | 线性对数几率 | 类别概率 | 条件负对数似然，即分类交叉熵 |
| 高斯判别分析，共享协方差 | 参数化 | 概率 | 线性对数后验之差 | 类别概率 | 带标签数据的联合似然 |
| 伯努利朴素贝叶斯 | 参数化 | 概率 | 二值特征的线性对数几率 | 类别概率 | 带标签数据的联合似然，即类别比例与类内特征概率 |
| 高斯核 SVM | 非参数化 | 非概率 | 非线性得分 | 得分、类别 | 特征空间中的间隔目标 |
| 二次判别分析 | 参数化 | 概率 | 一般为二次边界 | 类别概率 | 带标签数据的联合似然 |
| 固定结构、类别概率读出的非线性神经分类器 | 参数化 | 概率 | 非线性得分 | 类别概率 | 分类交叉熵 |
| 硬投票 $k$ 近邻 | 非参数化 | 非概率 | 局部投票形成的分段规则 | 类别 | 无参数拟合目标；查询时按距离取 $k$ 个邻居并硬投票 |
| 硬标签决策树，叶数可增长、按基尼不纯度分裂 | 非参数化 | 非概率 | 条件分支与分段规则 | 类别 | 逐步最大化基尼不纯度下降 |

表 2.2 分类模型的五维比较。表中采用所列的具体版本；概率模型均可进一步返回最大概率类别。“概率语义”按是否建立类别或联合分布判断，不能只由最终是否返回标签判断。

先沿关系形式一列比较。线性 SVM、逻辑回归、共享协方差的高斯判别分析和表中伯努利朴素贝叶斯，都用预先确定数量的参数得到线性得分或线性对数几率。但线性 SVM 以间隔目标学习得分，不建立类别分布；逻辑回归直接拟合 $p(y \mid \boldsymbol{x})$；另两者先拟合 $p(y)p(\boldsymbol{x} \mid y)$，再求类别后验。因此，边界同为直线并不意味着概率假设和训练准则相同。

当直线无法区分类别时，这几种设定可以沿不同方向扩展。SVM 改用高斯核，保留间隔准则和得分输出，边界可以弯曲，表示规模也可能随支持向量增长。高斯判别分析改用各类不同协方差，仍以联合似然训练参数化概率模型，却一般产生二次边界。固定结构神经分类器则与逻辑回归一样直接拟合类别条件分布、使用分类交叉熵，但中间层能够形成非线性得分。非线性能力增加并不必然改变参数化归类或概率语义，候选关系的范围与容量却可能随之改变。

另两种方案从局部信息确定类别。硬投票 $k$ 近邻先保存样本，再于查询时选择邻居并投票；硬标签决策树逐步选择分裂条件，最终在叶节点给出类别。两者的表示规模均可随数据增长，表中版本也都不显式建立类别概率。不过，近邻形成局部投票规则，树形成条件区域；前者没有参数拟合

步骤，后者按基尼不纯度的下降选择分裂。相同的类别接口因而对应不同的形成过程。

再沿输出一列回看，同样的得分或类别概率可以来自不同表示与准则。表中的硬投票和硬标签只限定本次比较的版本；若把近邻频率或叶节点类别比例用作概率估计，就需重新说明概率语义及接口。方法名称允许多个版本，具体设定才给出此次比较的依据。

### 2.7.3 聚类模型的五维比较

取消邮件标签以后，我们要决定哪些邮件归在一起。分组可以依据同一中心附近的位置、同一潜在分布，或邻近样本形成的连通区域。表2.3列出七个版本，先比较各自的分组依据，再查看它们怎样表示群组、返回结果。

| 具体模型设定 | 参数化方式与表示规模 | 概率语义 | 关系形式 | 输出接口 | 损失与学习准则 |
|---|---|---|---|---|---|
| K-means | 参数化 | 非概率 | 线性两两分配边界 | 簇编号 | 样本到中心的平方距离 |
| 高斯核 K-means | 非参数化 | 非概率 | 非线性分配边界 | 簇编号 | 核特征空间中的平方紧凑性 |
| 模糊 C 均值 | 参数化 | 非概率 | 隶属度非线性；硬分界线性 | 隶属度向量、编号 | 隶属度加权的簇内平方距离 |
| GMM，共享协方差 | 参数化 | 概率 | 线性两两分配边界 | 组别概率、编号 | 观测数据的似然 |
| GMM，不同协方差 | 参数化 | 概率 | 一般为二次分配边界 | 组别概率、编号 | 观测数据的似然 |
| DBSCAN | 样本内邻域图随 $n$ 增长 | 非概率 | 线性/非线性不适用；邻域连通关系 | 簇编号、噪声标记 | 邻域计数与连通规则，无统一的误差最小化目标 |
| Ward 层次聚类 | 含 $n$ 个叶节点的样本内层次树 | 非概率 | 线性/非线性不适用；逐步合并的层次关系 | 层次树、截取后的簇编号 | 每步最小化簇内平方离差的增量 |

表 2.3 聚类方法的五维比较。参数化设定固定输入维数与中心或成分数。DBSCAN 与 Ward 层次聚类主要组织已有的 $n$ 个样本，第二列记录其邻域图或层次树怎样随样本数增长，而不把输出标签数量当作模型参数；二者也不直接对应可按线性或非线性归类的新输入预测函数。

K-means 以有限中心描述群组，按最近中心分配样本，用平方距离评价紧凑性；两中心之间的分配边界是线性的，见式(2.9)。高斯核 K-means 保留中心与紧凑性准则，却在核特征空间中比较样本和原型，原空间的边界由此可以弯曲。原型通常借助训练样本表示，表示规模可以随数据增加。二者均为非概率模型，但标准版本采用参数化的线性分配关系，高斯核版本采用非参数化的非线性关系[9]。

群组交界处的样本未必需要立刻归入唯一中心。**模糊 C 均值**（fuzzy c-means）为各簇返回隶属度，记录样本参与各簇计算的程度，再据此加权簇内平方距离。隶属度虽非负且总和为一，却并非由观测分布推得的组别后验。只保留最大隶属度时，分配回到最近中心规则。因此，它与 K-means 都用有限中心且无概率语义，差别主要在于输出及距离的加权方式[10]。

要让归属具有概率含义，我们需要为观测和组别建立分布。GMM 用混合比例及多个高斯成分描述联合分布，以数据似然学习参数，再用后验表

[9] I. S. Dhillon, Y. Guan, B. Kulis, *Kernel k-Means, Spectral Clustering and Normalized Cuts* In Proceedings of the Tenth ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 2004, pp. 551–556

[10] J. C. Bezdek, R. Ehrlich, W. Full, *FCM: The Fuzzy c-Means Clustering Algorithm* In Computers & Geosciences, 1984, vol. 10, no. 2-3, pp. 191–203

示组别概率。共用协方差时，两成分对数后验之差的二次项抵消，形成线性边界；协方差不同时一般保留二次项。两个版本均为参数化概率模型，也都返回组别概率，关系形式却不同。共享协方差 GMM 与 K-means 都能给出线性两两边界，但一个优化似然，一个按几何距离分组，概率语义不能由边界形状决定。

弯曲群组有时难以用单个中心或高斯成分描述。DBSCAN（density-based spatial clustering of applications with noise）先按邻域样本数识别稠密区域，再沿连通关系扩展群组，并将未能归入这些群组的点标为噪声。这里的密度是邻域计数，未建立归一化的观测概率分布。它组织已有 $n$ 个样本及其邻域关系，规模随 $n$ 增长；新样本的归属还需另行规定冲突和拒绝规则，不能直接沿用为固定预测函数[11]。若要保留不同粗细的分组，可采用**凝聚层次聚类**（agglomerative hierarchical clustering），逐步合并并保存一棵树。表中的Ward **方法**每次从当前的簇对中，选择使簇内平方离差增量最小的一对进行合并；所得树以已有 $n$ 个样本为叶节点，可在不同层级截取。它与 K-means 都重视平方紧凑性，但返回层次关系，新样本的插入同样需要额外规则[12]。

比较这些方案时，我们实际在选择要保留哪种群组信息。核表示可形成弯曲边界，隶属度或后验概率可保留多重归属，但二者解释不同；邻域关系可保留局部连通形状，合并树可保留多个分组层级。最终即使都输出簇编号，“为何归在一起”的依据也不相同。

[11] M. Ester, H.-P. Kriegel, J. Sander, X. Xu, *A Density-Based Algorithm for Discovering Clusters in Large Spatial Databases with Noise* In Proceedings of the Second International Conference on Knowledge Discovery and Data Mining, 1996, pp. 226–231

[12] J. H. Ward Jr., *Hierarchical Grouping to Optimize an Objective Function* In Journal of the American Statistical Association, 1963, vol. 58, no. 301, pp. 236–244

### 2.7.4 模型组合与选择

实际系统还可把多个模块连接起来。PCA 之后使用 K-means，是先压缩表示再分组；神经网络之后接线性分类器，是先形成非线性特征再计算线性得分。对后一个系统，最后一层线性并不意味着整体对原输入线性。描述组合时，需要逐个检查模块，也要说明它们传递什么结果。

模块的连接方式还涉及怎样训练。分阶段方案先学习上游表示，再固定它训练下游模型；端到端方案按最终目标共同调整相关参数。上游目标是否保留了下游所需的信息，需要专门检查：压缩器可能重构得很好，却删除了分类所依赖的微小差别。

多个模型也可以对同一个输入共同预测，称为**集成学习**（ensemble learning）。随机森林汇集多棵树，梯度提升逐步加入模型改善已有预测。说明这样的系统时，既要交代基模型怎样产生差异，也要写清各输出怎样合成最终结果。

五维描述明确了模型假设，却还不能决定哪种方案在当前任务中更好。我们需要先按任务约定评价指标及其优劣方向，在相同的验证数据与可用

信息条件下比较，再结合数据需求、存储与查询成本、解释需求，以及分布变化下的可靠性作出选择。

## 2.8 本章小结

本章从权重、规则树与近邻的差别出发，建立了五个比较维度。模型族限定候选关系，参数或实例表示决定实际使用的关系，学习算法再依据数据作出选择。将这三个层面说明以后，才可以分别讨论参数化方式与表示规模、概率语义、关系形式、输出接口，以及损失与学习准则。

参数化方式说明表示受到的限制，概率语义说明是否用分布描述变量，关系形式说明变量怎样联系，输出接口说明交付的结果及其含义。损失与学习准则则把任务评价接到候选模型：可以比较逐样本答案、对象之间的关系，或整段轨迹；没有显式拟合目标的方法要说明例外及使用规则。这一准则属于完整学习设定，不能视为表示本身的内在属性。五项要分别判断，也需互相配合：线性与非线性计算都可用于概率预测，固定参数也可确定分布；类别编号和簇编号形状相同，评价依据却不同。

**延伸阅读** 下一章先转向经验与反馈：第3章会说明它们改变时，学习怎样组织。第2部分再在明确条件下研究算法能否从有限经验获得低风险结果，第3部分检查应用中的环境、群体、权限与风险要求。模型细节将在第三卷“模型”的“经典模型”部分、第三卷“模型”的“神经网络模型”部分和第三卷“模型”的“概率图模型”部分分别展开。

第 3 章

# 范式简介

第 1章用训练邮件的标签给分类预测计分，再据此调整模型。如果标签只覆盖少量邮件，这条学习途径还能怎样扩展？下棋或控制机器人又很难为每种处境预先填写正确动作，系统常只能观察行动结果。长期运行还会带来新数据、新任务，以及数据分散在不同位置的限制。要处理这些问题，我们需要进一步说明经验怎样进入学习。

学习范式规定可以利用的经验、反馈来源，以及组织学习的方式。它与任务、模型分工不同：任务规定要完成什么，模型表达可能的规律，范式规定凭什么经验和反馈学习这些规律。表 3.1继续用垃圾邮件系统说明三个层次。

| 层次 | 回答的问题 | 垃圾邮件例子 | 与其他层次的关系 |
| --- | --- | --- | --- |
| 任务 | 系统要完成什么？ | 判断一封邮件是否为垃圾邮件 | 可以更换模型，任务仍是分类 |
| 模型 | 用什么形式表示输入与输出的关系？ | 逻辑回归、决策树或神经网络 | 同一模型可以用于不同学习范式 |
| 学习范式 | 系统利用什么经验和反馈？ | 从带类别标签的历史邮件学习 | 可以更换模型，仍是监督学习 |

表 3.1　任务、模型和学习范式描述机器学习问题的不同层次。它们相互关联，但不存在固定的一一对应关系。

同一分类任务可以使用完整标签，也可以把少量标签与无标签邮件结合，还可以先从文本学习特征，再根据标签学习类别。这里的表示仍指第 1章所说的输入描述，既包括词数、链接数，也包括模型学习的特征。神经网络能够接受不同来源的反馈，所以只说采用深度学习，尚未说明学习范式；文本或图像生成只规定任务，同样不足以确定经验和目标的来源。

本章先比较三种基本反馈：配对目标、数据中的结构，以及行动后果的奖励。随后，我们讨论标签不足时怎样获取与利用额外知识，数据和任务变化时怎样共享、保留及迁移已有知识，再加入学习时序和协作环境的限制。章末通过组合案例检查这些设定怎样在一个系统中配合。

这一顺序按问题组织内容，各组可以重叠。同一方法既可能规定反馈来源，又可能规定知识复用或协作方式。因此，辨认系统的范式需要逐项检查其条件，而不是把它放入唯一类别。

本章建立基本区别，第四卷再按研究问题展开。第四卷“范式”的“强化学习”部分研究交互决策；第四卷“范式”的“知识的获取”部分研究有限标签和其他训练依据的取得与处理；第四卷“范式”的“知识的演进与迁移”部分研究已有知识的复用、更新及共享。本章对应三节为这些部分提供入口，后续概述章再建立完整问题地图。在线与联邦学习分别限定时序和协作环境，可以与这些问题结合，因而不各自对应第四卷的独立部分。

## 3.1 监督学习

已有一批邮件及其类别时，我们可以先让模型预测，再以已知类别检查结果。利用输入及其配对目标学习预测关系，称为**监督学习**（supervised learning）。配对示例既规定希望预测的对象，也为模型的选择提供依据；学习所得关系随后用于新输入。

目标随任务而变：邮件分类预测类别，房价回归预测成交价格，机器翻译预测对应译文，还可预测次序或其他序列。尽管输出不同，它们都能用已有目标评价预测，并据此指导学习。监督学习因而不限于分类和回归。

目标也未必来自手工标注。手写数字的类别常由人提供，房价可以取自成交记录，天气目标可以来自之后的实际观测。它们共同给出训练示例希望预测的对象，而不是要求训练时有人不断干预。面对待预测的新邮件或房屋，模型使用已经学到的关系，此时不能再把未知目标作为输入。

MNIST 让这一分工具体可见：数据把手写数字图像与数字类别配对，研究者据此训练并检验模型能否识别新笔迹[1]。图 3.1中，图像送入模型以产生预测，标签单独用于比较；使用阶段只有新图像，由训练好的模型判断类别。

[1] Y. LeCun, L. Bottou, Y. Bengio, P. Haffner, *Gradient-Based Learning Applied to Document Recognition* In Proceedings of the IEEE, 1998, vol. 86, no. 11, pp. 2278–2324

比较结果还要变成可以用于学习的量。真实数字为“3”时，我们不但能检查选出的类别，还能检查模型给“3”的概率；房价任务则能检查预测与成交价的偏差。损失函数把任务要求转成可计算评价，学习算法再利用它调整模型，使训练样本上的预测更符合目标。具体算法可以不同，但都需说明怎样评价候选预测。

训练中的改善能否延续到新输入，还需另外检查。测试样本及其标签应不参与训练和调参，标签只用于评价最终预测。若根据测试答案继续改模型，我们评价的仍是它适应已见答案的能力，无法据此判断面对新样本的表现。

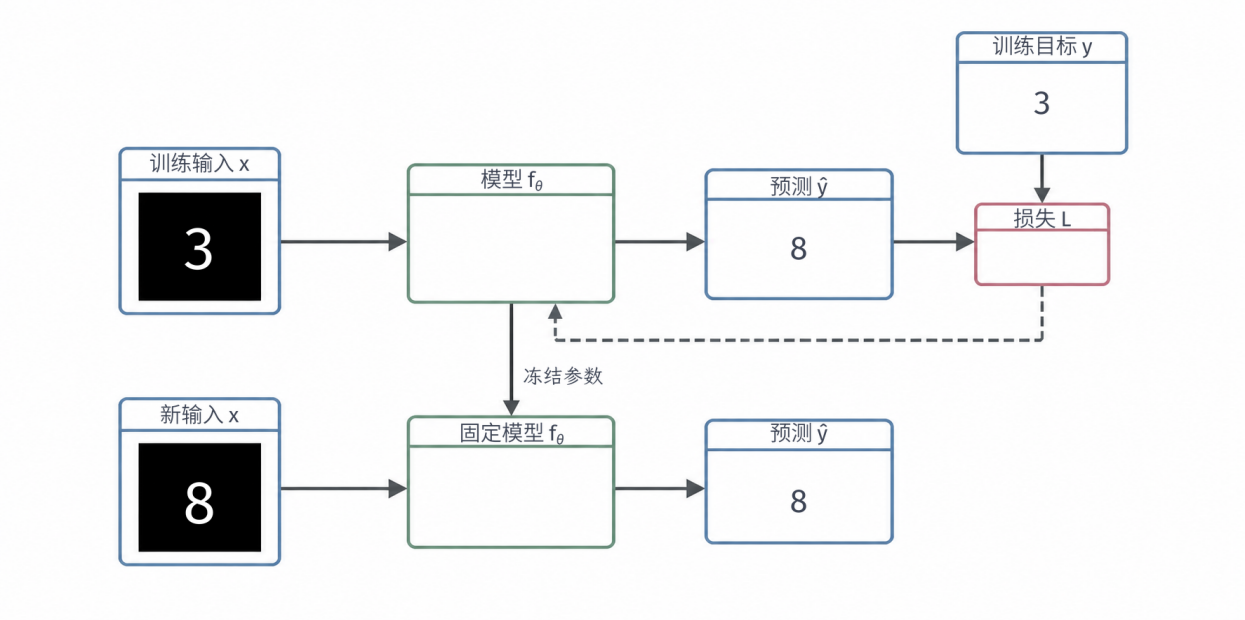


图 3.1 监督学习中的训练与使用。训练时图像进入模型，目标标签单独进入损失比较，虚线反馈用于更新参数；使用时只提供新图像。训练行中，数字 3 被暂时预测为 8，原标签 3 只进入比较；使用行没有提供目标。数字字形为教学构造，不是 MNIST 原始样本；模型框不指定网络架构。

可靠目标与样本覆盖共同限制监督学习。某类笔迹若从未进入训练集，或标签含有系统性错误，多训练几轮不能自动弥补；训练中的输入与目标关系能否延续到应用场景，也不能由数据集名称保证，而需在目标场景独立检验。标签规定了希望预测什么，有限标签却未必代表所有新情况。

## 3.2 无监督学习

现在考虑没有逐样本答案的一批新闻。我们仍可观察哪些词经常共现、哪些文档彼此相近，再用这些规律整理内容。这样从数据发现结构或分布，而不依赖逐样本目标答案的设定，称为**无监督学习**（unsupervised learning）。

要寻找的规律由用途决定。**聚类**（clustering）依照相似性形成群组，可用于探索购买行为；**降维**（dimensionality reduction）以较少变量保留重要变化或邻近关系，可服务于可视化、压缩和后续分析；**分布建模**（distribution modeling）描述观测出现的规律，可用于采样或识别不常见观测。没有标签并不妨碍设定这些目标，只是检查依据转向了数据及所作假设。

顾客聚类说明表示怎样影响发现的结构。只比较购买金额，群组可能主要区分消费水平；加入购买时间与商品种类，就可能反映不同购物习惯。算法可以反复调整分组，让组内样本在选定表示下更相似，但最终分组始终依赖所用特征与相似性标准。省去答案以后，学习目标和假设仍然存在。

一篇新闻可能同时涉及体育和经济，唯一群组会遗漏这种混合。潜在狄利克雷分配（latent Dirichlet allocation, LDA）因此用多个主题共同描述文档，各主题再由词语概率刻画。原始研究在 16,000 篇 TREC AP 新闻上学习 100 个主题，并观察各主题的高概率词[2]。文档没有预填主题标签；学习利用同一文档中的词语共现形成潜在主题，研究者随后根据代表词解释其含义。图 3.2展示了整批文档提供统计规律、所得模型再描述新文档主题组成的过程。

[2] D. M. Blei, A. Y. Ng, M. I. Jordan, *Latent Dirichlet Allocation* In Journal of Machine Learning Research, 2003, vol. 3, pp. 993–1022

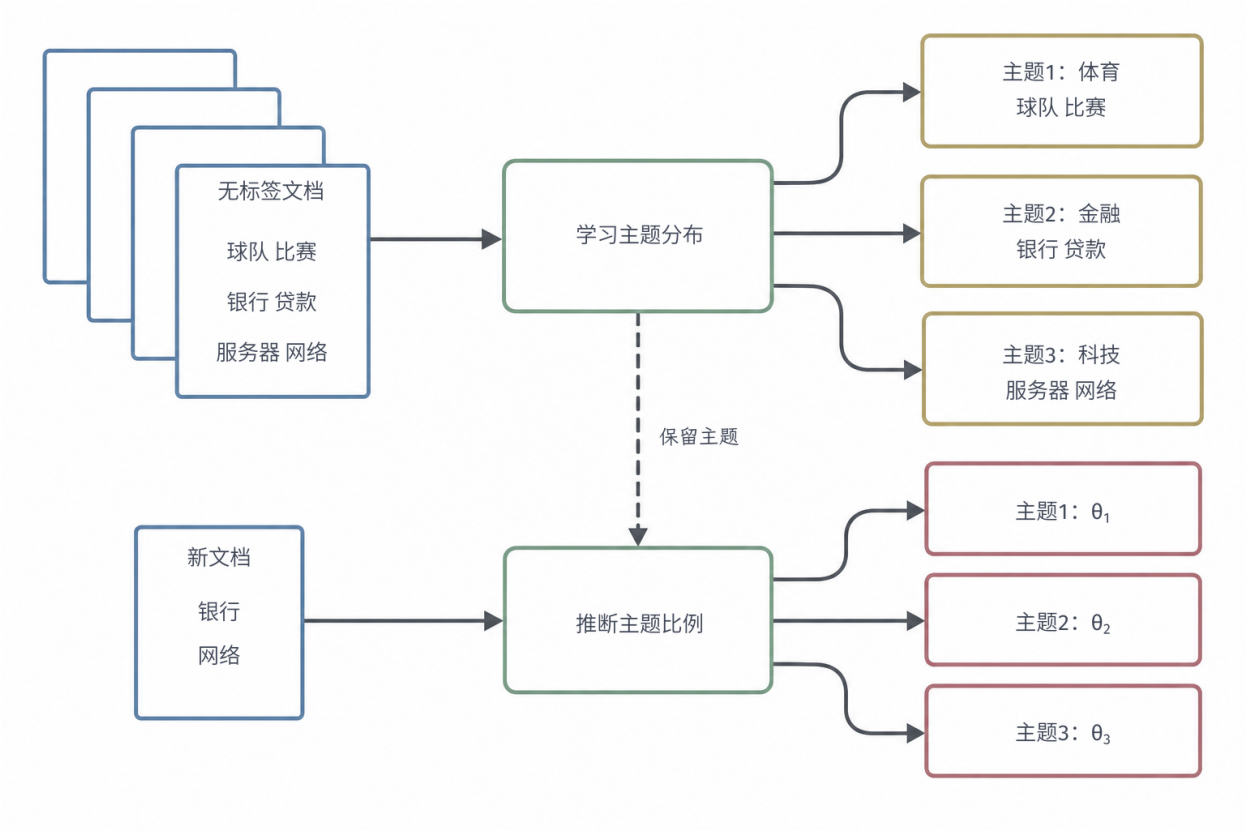


图 3.2 无监督主题发现的过程示意。没有主题标签的新闻集合提供词语共现信息，学习过程形成若干潜在主题；同一篇文档可以由多个主题共同构成，主题名称是在结果解释阶段由人给出的。

若预先规定“体育”“财经”并提供类别示例，问题便是监督分类；主题发现则先学习共现模式，后由人解释和命名。事后把主题命名为“体育”，不会使这个名称成为训练时的标签。混合主题还允许同一新闻同时保留体育与经济成分。

发现的坐标和群组未必对应业务概念。把顾客的几十项特征压缩成两个坐标，可以画图观察邻近关系，但坐标轴未必具有“收入”或“年龄”的含义，分离的群组也未必是业务要区分的类型。计算出的结构与人赋予的解释需要分别检查。

新闻主题可以从三方面检查：代表词能否概括对应文档的内容，更换一批同来源新闻后各主题的高概率词是否大体保留，以及按主题整理是否减少人工查找相关文档的时间。它们分别提供解释、稳定性及实际用途的证据。图上群组清晰只呈现一种几何现象，还不足以证明结果有效。

## 3.3 强化学习

下棋时，当前落子既改变棋盘，也改变之后的选择；机器人移动和车辆换道同样会改变后续处境。已有数据上的预测误差于是不能完整评价行动，我们还必须追踪它留下的后果。

利用行动后果的奖励学习决策，称为**强化学习**（reinforcement learning），通常以多步奖励构成的预期累计回报为目标。决策者称为**智能体**（agent），与之交互的外部世界称为**环境**（environment），环境给出的数值评价称为**奖励**（reward）。下棋程序作出落子，棋局与对手回应形成环境反馈；评价策略时还要考虑不同交互经历的平均结果。

智能体依据当前可用信息选择动作，所用规则称为**策略**（policy）。**状态**（state）描述环境处境，**观测**（observation）是智能体实际得到的信息。机器人摄像头只能看到某个方向，两者因而未必一致；必要时，策略要结合此前的观测和动作，不能把一帧画面直接当作完整状态。

建立基准时，我们先固定任务与单个智能体，并采用 Markov 状态。在有限时域中，马尔可夫决策过程（Markov decision process, MDP）规定状态集、可选动作、初始状态分布、受控转移、阶段及终点奖励和时域。在固定时刻，给定当前状态与动作后，下一状态和奖励的分布不再依赖更早历史，这就是 Markov 条件。状态是否可见、转移是否已知、经验来自在线交互还是固定记录，则属于学习者的信息及访问条件，会改变方法和评价协议，不属于 MDP 元组本身（可参考第一卷“策略的价值与优化”章的“策略诱导的轨迹”）。

标签直接提供希望预测的对象，奖励通常只评价已采取动作的结果，并不列出正确动作。反馈还可能延迟：围棋的胜负要到终局才能确定，当前吃子较多并不保证最终获胜。强化学习因而需要关联当前选择与后续结果，不能把即时得分直接等同于长期目标。

一条交互轨迹记录状态、动作及其后果。将阶段奖励与终点奖励相加，得到这次执行的累计回报；策略的期望回报则按策略与环境产生各轨迹的概率取平均。这里以奖励越大越好；若改以成本评价，令奖励等于成本的负值，并将最大化与最小化成套转换（可参考第一卷“策略的价值与优化”章的“轨迹收益与策略价值”）。辨认范式时，我们检查策略与环境怎样产生轨迹，训练怎样使用过程或终点奖励，而不只看模型是否连续输出动作。**折扣因子**（discount factor）改变不同时间奖励的权重，长期平均回报则比

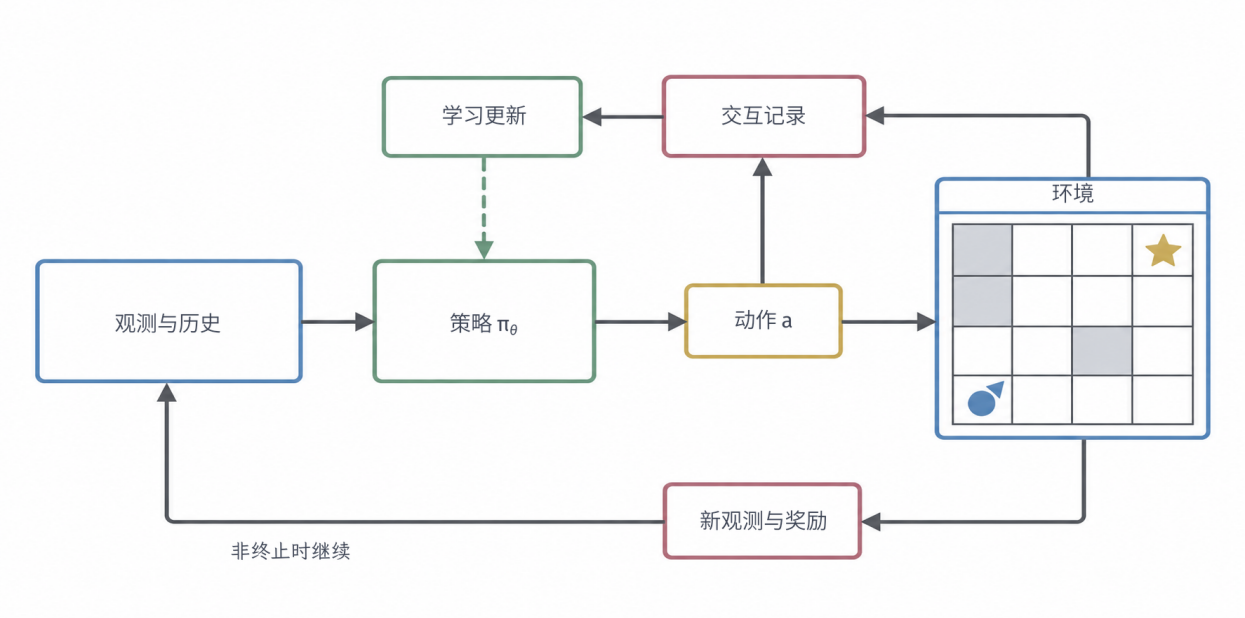


图 3.3 机器人探索中的强化学习交互。策略依据观测与历史选择动作，环境返回新观测与奖励；动作和环境反馈共同形成交互记录，学习过程据此更新策略，非终止时继续交互。格图中的机器人、障碍与目标仅为概念场景，不表示测量结果、精确状态转移或回合终止。奖励不是正确动作标签。

较单位时间的收益。使用这些准则时，应限定时域、平均方式和所需可积条件，并按任务加入风险要求[3]。

在线交互中，当前策略产生观测、动作和奖励记录，算法用记录评价长期后果并调整策略；新的策略又会改变下一轮经历。只重复已知有效的动作，可能错失更优选择；不断尝试未知动作，则可能牺牲已有收益。探索与利用的权衡因此同时涉及获取信息和取得回报[4]。

这些记录可以按不同方式进入策略改进。价值方法先估计状态或动作的长期后果，再据此选择；直接策略优化使用回报信号调整策略；**行动者—评论家**（actor–critic）同时维护策略和价值估计，让后者评价前者的更新。它们说明价值估计与策略更新怎样配合，具体算法由第四卷展开。

若能预测动作将怎样改变状态或观测及奖励，就可以在行动前比较后果。描述这类变化的**环境模型**（environment model）可以已知，也可以从数据学习，之后用于规划。模型提供了比较路径，评价仍需关联即时反馈与长期结果。

2015 年的深度 Q 网络（deep Q-network, DQN）研究在 49 款 Atari 游戏上采用相同基本算法和模型设定，利用游戏画面及分数学会控制[5]。智能体看画面、选按键，环境返回新画面与分数，再形成下一批经验。DQN 采用价值方法，估计按键可能带来的累计回报，而非只预测即时加分；游戏分数也没有直接告诉它应按哪个键。图 3.3借机器人探索展示同一分工：动作改变处境，后续观测与奖励进入学习。

[3] R. S. Sutton, A. G. Barto, *Reinforcement Learning: An Introduction*, MIT Press, 2018, 2nd ed.

[4] R. S. Sutton, A. G. Barto, *Reinforcement Learning: An Introduction*, MIT Press, 2018, 2nd ed.

[5] V. Mnih, K. Kavukcuoglu, D. Silver, A. A. Rusu, J. Veness, M. G. Bellemare, A. Graves, M. Riedmiller, A. K. Fidjeland, G. Ostrovski, S. Petersen, C. Beattie, A. Sadik, I. Antonoglou, H. King, D. Kumaran, D. Wierstra, S. Legg, D. Hassabis, *Human-Level Control through Deep Reinforcement Learning* In Nature, 2015, vol. 518, pp. 529–533

围棋中，棋盘对应状态，落子对应动作，终局胜负提供关键反馈。自我对弈可以继续产生棋局，让后续胜负用于学习不同局面的行动。第 3.7节以 AlphaGo 说明这类经验怎样与人类棋谱配合。

机器人可从摄像头、关节位置及力传感器取得观测，再选择移动关节、改变抓取姿态或行走方向。奖励可以评价抓取是否稳固、目标是否到达，以及动作是否平稳。不过，真实失败可能损坏设备，不能像游戏一样简单重开，取得经验本身就带有成本。

跟车、换道和路径规划也可写成序贯决策：车辆选择动作后，位置、速度及其他车辆的回应共同形成新状态，评价兼顾安全、效率与舒适。整个自动驾驶系统却包含不同学习问题，感知可利用监督或自监督反馈，决策需追踪动作后果。推荐、调度和能源管理也可能需要这种建模，是否采用强化学习要依据反馈与长期目标判断。

新闻推荐可以先采用简化设定：只检查展示后是否点击，不建模本次推荐怎样改变后续兴趣。但系统仍只能观察已选新闻的反馈，无法同时知道其他选择的结果。反复选择并积累这种奖励，构成**多臂老虎机问题**（multi-armed bandit）；选择前若还可见用户特征和候选新闻等信息，则构成**上下文老虎机问题**（contextual bandit）。Li 等人的推荐研究采用后一设定[6]。

[6] L. Li, W. Chu, J. Langford, R. E. Schapire, *A Contextual-Bandit Approach to Personalized News Article Recommendation* In Proceedings of the 19th International Conference on World Wide Web, 2010

老虎机设定不让当前动作通过改变环境状态影响后续奖励，但当前反馈会增加信息，影响之后的选择，仍存在探索与利用。若推荐对未来行为的影响也进入目标，就要扩大为序贯决策模型。因此，应用名称不能决定设定，关键是哪些行动后果被纳入评价。

无法承担在线试错时，可以先用模拟器学习，或以专家示范建立初始行为。**离线强化学习**（offline reinforcement learning）则使用已经收集的交互记录，学习时不再额外与环境交互[7]。这些途径减少真实试错，却各有经验限制：模拟器可能失配，示范可能错误或覆盖不足，历史记录也可能缺少将来重要的状态和动作。所得策略仍需检验，再逐步投入使用。

[7] S. Levine, A. Kumar, G. Tucker, J. Fu, *Offline Reinforcement Learning: Tutorial, Review, and Perspectives on Open Problems* In arXiv preprint arXiv:2005.01643, 2020

经验充分也不保证奖励完整表达任务。只奖励机器人迅速搬运，可能忽略物体受损；我们需要把损坏纳入评价，并为不可接受的行为加入约束。难以直接数值化的要求，可通过人对结果的偏好学习评价信号，也可由规则或验证器检查过程与最终结果。第 3.7节会介绍偏好与强化学习的组合。无论信号怎样构造，成功仍应依据实际任务要求检查，奖励提高不能替代这一判断。

示范还能直接提供动作依据：专家展示某种处境下的行动，学习者据此学习行为，称为**模仿学习**（imitation learning）。其中**行为克隆**（behavior cloning）把专家观测与动作配成输入和目标，采用监督学习。

但学习者一旦走偏，就可能遇到示范中没有的处境，随后错误继续累积。DAgger 让学习者实际行动，再请专家为遇到的状态提供动作，补充原示范的覆盖[8]。模仿与强化学习均可生成连续行动，区别在于训练主要使用动作示范还是结果奖励，不能只看使用时的行为形式。

示范也可用于推断专家为何选择这些动作。**逆强化学习**（inverse reinforcement learning）寻找能够解释示范的奖励函数，再用它学习策略[9]。路线可以反映对路程、障碍及安全距离的取舍，但同一行为往往符合多种奖励，有限示范一般不能唯一还原真实目标。推得奖励以后，还需检查它引导的行为。

上述基准固定任务和决策者，以期望回报比较策略。应用还可能要求跨任务复用经验、与其他会学习的参与者协作或博弈，以及控制严重损失、扰动和不安全行为。这分别改变任务、参与者和行为要求，平均训练奖励不能同时证明它们满足。可靠性评价必须限定运行范围、失败指标与证据，有限测试不能外推为任意环境保证。

第四卷“范式”的“强化学习”部分将沿这些问题展开：环境模型已知或未知时如何规划与学习，观测和经验受限时怎样决策，奖励难以获取或表达不准时怎样形成反馈，以及任务、参与者、风险和安全要求变化时怎样评价策略。

## 3.4 知识的获取

收集照片通常比确认物种容易，可靠任务标签因而可能成为学习的限制。预算有限时，我们要考虑让已有标签发挥更大作用、利用其余原始数据，或选择更值得新增标注的样本。这里关注的是训练依据怎样取得和使用。

训练依据不限于类别标签。我们把可指导训练的答案、样本关系、约束与目标统称为训练知识。人工、规则、模型和数据产生的内容在核验前都是候选知识；数量、置信度或训练损失均不能单独证明质量。知识不足也可能是覆盖不全、粒度失配、内容错误或过时，需要分别处理。

本节所谓高效，是在达到同一目标评价要求时减少人工任务标签，或在相同标注预算下相对于既定基线改善独立评价结果。它不承诺计算更少。比较时，应分别报告任务收益及人工、模型调用、计算和维护成本，而不能用候选标签或样本的新增数量代替收益。

我们先按半监督、自监督、弱监督、对比及主动学习辨认资源和训练信号。第四卷“范式”的“知识的获取”部分再按来源与处理职责组织：人工、规则、模型和数据提供候选依据，之后进行融合、评估与修正。两种组织并非一一对应。主动学习选择向人工询问的样本，标注函数使用规则，伪标签、教师输出和生成材料来自模型，自监督、对比及分组从数据内容或关系构造目标；半监督和弱监督可以合用多个来源。

[8] S. Ross, G. Gordon, D. Bagnell, *A Reduction of Imitation Learning and Structured Prediction to No-Regret Online Learning* In Proceedings of the Fourteenth International Conference on Artificial Intelligence and Statistics, 2011, pp. 627–635

[9] A. Y. Ng, S. Russell, *Algorithms for Inverse Reinforcement Learning* In Proceedings of the 17th International Conference on Machine Learning, 2000

### 3.4.1 半监督学习

商品类别已确定，但只有少量图片完成标注时，标签可以规定类别含义，其余图片可能补充光照、角度与背景的变化。**半监督学习**（semi-supervised learning）让有标签与无标签数据共同服务于目标任务，利用后者提供的输入规律扩展学习。

无标签图片如何进入训练？**自训练**（self-training）先以已有标签训练模型，再预测其余样本；采纳为临时目标的预测称为**伪标签**（pseudo-label）。原标签与选中伪标签一起参与后续学习，之后还可重新生成。预测提供了使用额外数据的途径，却没有因此成为真实答案。

筛选常依据**置信度**（confidence），即模型对当前预测的确定程度；分类时常以预测类别的概率作为置信度分数。但自信也可能伴随错误，反复学习错误伪标签会强化原误判。因此，筛选之外还需控制伪标签的权重或影响，不能将高置信度直接当作可靠性证据。

还可以不先决定类别，而是约束同一对象的预测。轻微改变亮度通常应保留动物类别，要求变换前后预测稳定便是**一致性约束**（consistency regularization）。同一原图产生的不同**视图**即使无标签，也能提供预测分歧作为调整依据。前提是变换保留任务含义：裁剪若删除动物，要求类别不变反而会误导模型。

样本之间的相似性提供另一条途径。**基于图的方法**（graph-based methods）将样本作为节点、相似关系作为边，再让少量标签影响邻近无标签节点。经典图半监督方法以两类样本共同构图，要求相邻预测接近[10]。聚类思路则假设密集群组往往对应同类。两者都需要任务相关的相似性，背景颜色相近并不保证类别相同。

FixMatch 将伪标签与一致性合用：先预测弱变换的无标签图片，最大类别概率达到预设阈值时采用其类别，再要求同图强变换后的预测一致[11]。真实标签约束类别含义，这两项要求把训练延伸到没有提供答案的图片。

CIFAR-10 有十类物体，相关实验只揭示少量训练图的类别，其余训练图参与上述过程。这里的无标签指答案被隐藏，训练不得读取原本保存的真实类别。图 3.4说明两路数据怎样共同用于分类。

[10] X. Zhu, Z. Ghahramani, J. Lafferty, *Semi-Supervised Learning Using Gaussian Fields and Harmonic Functions* In Proceedings of the Twentieth International Conference on Machine Learning, 2003, pp. 912–919

[11] K. Sohn, D. Berthelot, C.-L. Li, Z. Zhang, N. Carlini, E. D. Cubuk, A. Kurakin, H. Zhang, C. Raffel, *FixMatch: Simplifying Semi-Supervised Learning with Consistency and Confidence* In Advances in Neural Information Processing Systems 33, 2020, pp. 596–608

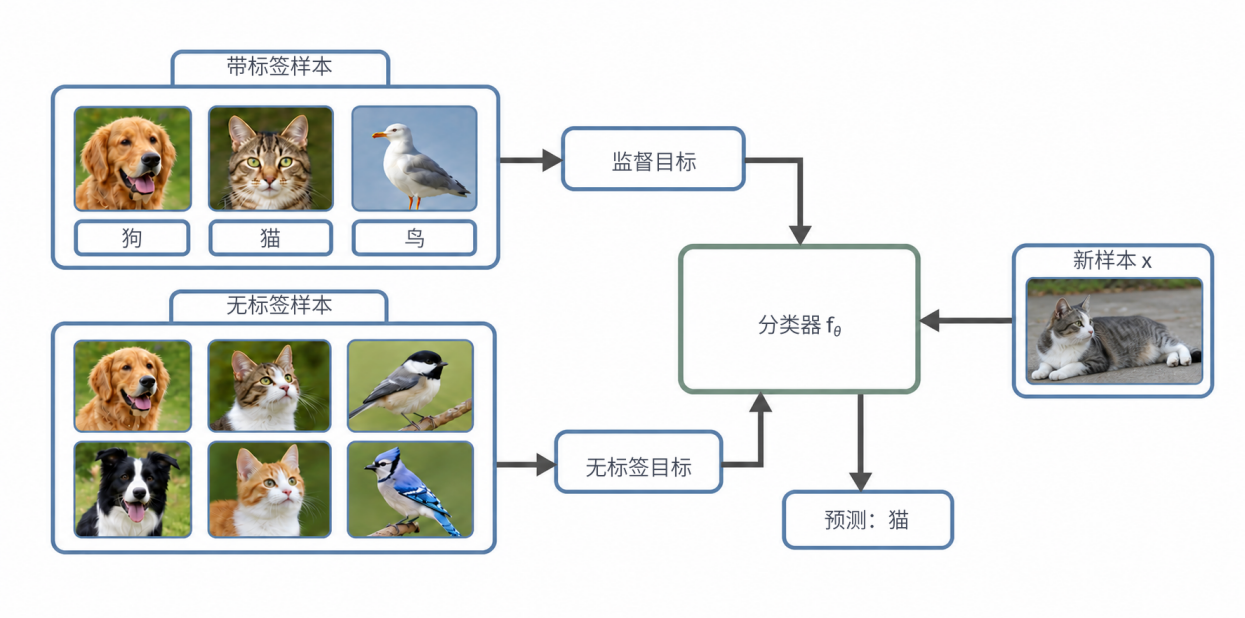


图 3.4 半监督学习的过程示意。少量带类别标签的图片规定目标，大量无标签图片提供额外结构信息，两路经验共同用于形成分类能力，汇入同一分类器。模型框不指定网络结构；动物图片为教学构造。无标签图片的隐藏真值不能作为训练答案使用。

这个设定还要求额外图片与十类识别任务相关。若加入类别范围之外的图片，模型可能仍自信地赋予已知类别，再将它作为伪标签学习。额外数据的适用范围因而需要检查，数量增加本身并不保证帮助。

预测范围也需明确。若学习一条处理未来新输入的规则，称为**归纳学习**（inductive learning）；若待预测图片已给定，学习利用其结构为这批特定输入补全答案，称为**直推学习**（transductive learning），也称转导学习。直推支持向量机采用了预先给定待分类样本的设定[12]。

归纳与直推限定输入可见性及评价范围，半监督则限定标签资源，两者是不同维度。半监督可以使用任一种预测设定。直推允许查看待预测输入，却仍应隐藏它们的答案；这批输入上的评价也不能替代未来新样本的表现。

半监督仍用已有类别标签规定任务。若这些标签尚不存在，我们可以从原始数据构造别的有答案问题，先学习日后可能复用的规律。

[12] T. Joachims, *Transductive Inference for Text Classification using Support Vector Machines* In Proceedings of the 16th International Conference on Machine Learning, 1999, pp. 200–209

### 3.4.2 自监督学习

完整文本没有情感标签，却保留着每个词。暂时隐藏一部分内容，就能以可见上下文为问题、原内容为答案，构造无需另行标注的训练示例。这为标签稀缺提供了另一种训练依据。

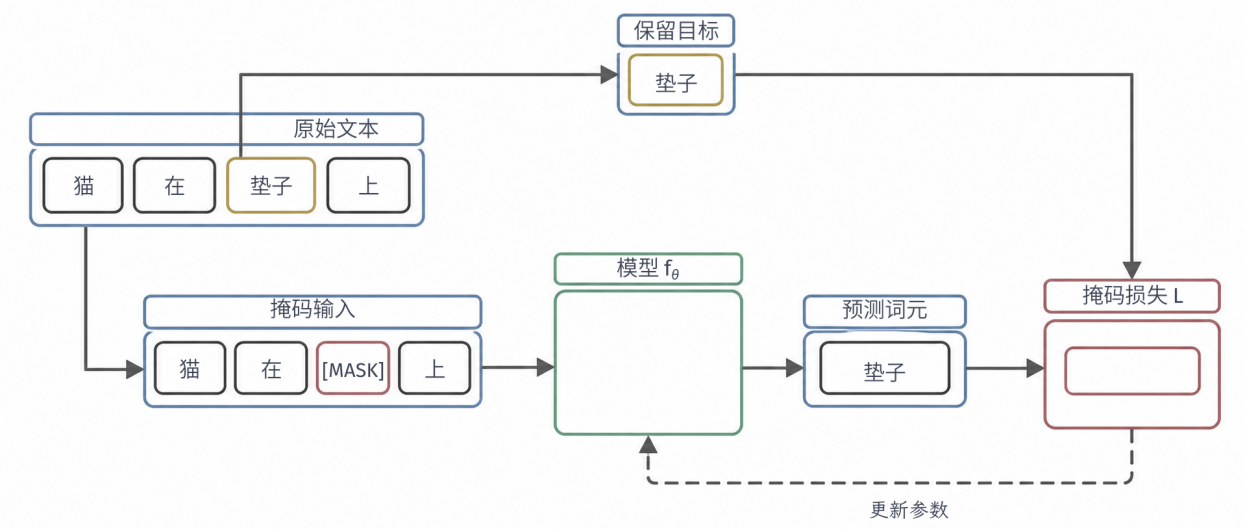


图 3.5 掩码预测以“猫在垫子上”为教学例子。输入将“垫子”替换为 [MASK]，原词单独保留为比较目标；模型只能读可见上下文，不能读被保留的答案。可见词元共同进入模型，灰色虚线将损失反馈到参数；模型框不指定网络结构。

从数据内容或关系构造目标，称为**自监督学习**（self-supervised learning）。遮挡恢复、后续内容预测和不同视图匹配都可采用这种方式。“自”限定目标来源，遮什么、比什么仍需设计。我们希望补词促成语法与语义学习、图像恢复促成纹理和物体关系学习，但究竟获得哪些能力还需用实际任务检验。

BERT 的掩码预测给出具体过程[13]。文本先分成**词元**（token），它可以是字、词或词的一部分；训练随机选择部分词元，将其中多数换成掩码，再用左右上下文预测原词元。原文同时提供输入与答案。例如教学句子“猫在垫子上”隐藏“垫子”后，剩余内容进入模型，原词元单独用于比较。图 3.5展示了两路信息，模型预测时不能读到保留答案。

配对构造完毕，就可比较预测与答案并调整参数。下一词元预测只以目标之前的文本为输入，以紧随其后的原词元为答案，也能批量生成示例。辨认自监督时应追溯目标的构造：掩码任务恢复原文，情感分类则预测另行规定的评价类别。是否人工手填标签并不足以区分二者。

同一批新闻还可用于前述主题发现。主题模型从共现学习潜在结构，掩码任务则把数据转换成显式输入和恢复目标，逐次比较预测与答案。二者都利用缺少人工任务标签的数据，也都包含目标和人为假设；差别并非是否存在目标函数。

广义无监督学习可包含自监督，因为它不依赖额外人工任务标签。本书为说明信号怎样构造，将自监督单列讨论；这是一种内容组织方式，而非要求分类互斥。

[13] J. Devlin, M.-W. Chang, K. Lee, K. Toutanova, *BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding* In Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, 2019, pp. 4171–4186

自监督目标可直接用于文本生成，也可先学习表示，再服务分类或问答。先积累可复用知识的阶段称为**预训练**（pre-training），后续具体用途称为**下游任务**（downstream task）。例如，先学习文本与上下文关系，再用少量情感标签学习评论类别；两个阶段利用的目标来源不同。

预训练所得规律还不能自动规定下游类别，最终任务可能需要标签或其他说明。构造目标也可能让模型走捷径：若局部词语搭配足以恢复遮挡，完成该目标未必要求理解整段文字。因此，是否帮助下游任务，要以实际评价为依据。

### 3.4.3 弱监督学习

还可利用成本较低、质量不完善的现有标注。汽车定位需要位置答案，但现有数据可能只注明“图中有汽车”，甚至网页标签与内容不符。**弱监督学习**（weakly supervised learning）研究怎样利用不完整、不精确或不可靠的监督，让学习不必等到所有标注达到理想标准才开始。

一种常用划分把部分样本缺少标签称为监督不完整（incomplete supervision），把整图类别不能提供位置等所需信息称为监督不精确（inexact supervision），把标签与内容不符称为监督不准确（inaccurate supervision）[14]。第 3.4.1节的半监督学习主要处理第一种，属于广义弱监督范围。本节转向粗粒度、错误标签和规则监督。

领域经验也可先转成批量规则。Snorkel 允许专家编写**标注函数**（labeling function），依据关键词、模式或外部知识作判断，并在依据不足时弃权。例如，“含链接”提示垃圾评论，也可能误伤正常分享。系统综合一致、冲突与弃权的规则输出，估计类别概率，再以概率标签训练最终模型[15]。图 3.6中的汇合，表示从多条候选判断形成训练监督，而非直接确认真值。

规则还可来自事实关联、类别约束或结构要求，产生标签、候选范围及关系判断。未触发只表示没有给出判断，不能自动记为负例。使用时应记录规则的形成依据、适用对象和冲突处理方式，才知道候选信号代表什么。

批量规则减少逐条标注，也会传播自身局限。多条规则都依据链接，即使一致也可能共同误判正常分享；粗标签则可能缺少任务需要的位置细节。最终模型仍需独立可靠标签评价，符合规则不能证明已学会目标能力。

[14] Z.-H. Zhou, *A Brief Introduction to Weakly Supervised Learning* In National Science Review, 2018, vol. 5, no. 1, pp. 44–53

[15] A. Ratner, S. H. Bach, H. Ehrenberg, J. Fries, S. Wu, C. Ré, *Snorkel: Rapid Training Data Creation with Weak Supervision* In Proceedings of the VLDB Endowment, 2017, vol. 11, no. 3, pp. 269–282

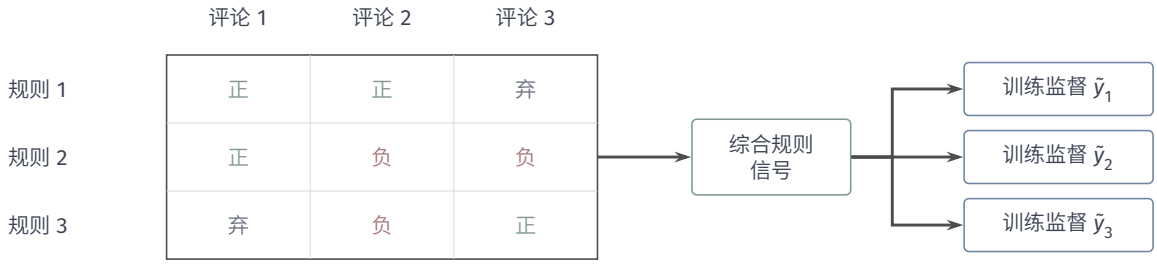


图 3.6 三条规则在三个未标注评论上的教学投票。正、负、弃分别表示两种倾向与弃票；同一列可能存在冲突。综合规则信号形成训练监督 $\tilde{y}_i$，图中不规定合并算法，也不把某条规则输出等同于真实标签；评价仍使用独立可靠标签。

从整图标签学习位置，需要把粗监督与区域预测联系起来。我们可把图像视为多个候选区域：整图有汽车，意味着至少一个区域包含汽车，而非每个区域都是汽车。这是**多示例学习**（multiple-instance learning）的典型设定，监督约束对象组而未逐一给出答案。若把整图标签复制到每个区域，背景就会被错误标为汽车。

对带噪声标签（noisy labels），可以识别可疑样本并减弱其影响，也可建立标签出错的模型，例如用少量核验样本估计可靠性，再调整训练。但难学不等于错标，少见而正确的情形同样会令模型犯错。处理弱监督要利用已知不确定性，避免无条件把现有记录当作真值。

多来源规则通常先经过可靠性估计和综合，再与原始样本一起训练最终模型。综合时不能把近似规则当作独立证据：仅关键词略有差异的两条规则可能重复同一线索。来源的准确性、覆盖及依赖关系需要进入处理，并允许保留不确定结果。

规则之后继续训练，是希望模型从原内容学习更可推广的关系，处理规则未覆盖的输入。但规则中的系统性错误也可能被继承，所以这一步是否成功，要由独立样本上的可靠评价决定。

### 3.4.4 对比学习

已知对应关系也可直接指导表示。一张照片改变颜色或取景后，两个视图同出一图这一关系仍可已知，无需先有类别标签。**对比学习**（contrastive learning）利用匹配与不匹配关系构造目标：使用相似度或匹配得分时，提高匹配对、降低对照对的数值；使用距离时，则缩短匹配距离、增大对照距离。希望匹配的对象构成**正样本对**（positive pair），不匹配对照构成**负样本对**（negative pair）。正负限定的是关系，不能与二分类类别混淆；距离或相似度的选取还需符合表示及下游用途。

SimCLR 先用没有提供类别标签的图片学习表示，再检验这些表示是否帮助分类。原研究在 ImageNet 等数据上开展这一过程，之后用标签训练

分类器或调整模型[16]。类别标签进入评价或后续训练，并未进入前一阶段的匹配构造。

具体目标是找出同一原图的另一个视图。每批原图各经两组随机裁剪、颜色变化等变换，再由共享模型形成表示；同源视图互相匹配，其余原图的视图提供对照。只要求同源接近，会允许所有图都映为同一点；加入对照，才同时要求保留变换下的联系及不同图片之间的差别。

图 3.7用两个同源视图和另一幅猫图作对照。模型在此不知道“鸟”“猫”类别，信号来自视图的原图来源，所以属于自监督。反复比较可能促成变换下稳定的特征，后续再检验分类用途。图中位置只表示训练所要求的关系，并非实验测得的表示分布。

[16] T. Chen, S. Kornblith, M. Norouzi, G. Hinton, *A Simple Framework for Contrastive Learning of Visual Representations* In Proceedings of the 37th International Conference on Machine Learning, 2020, pp. 1597–1607

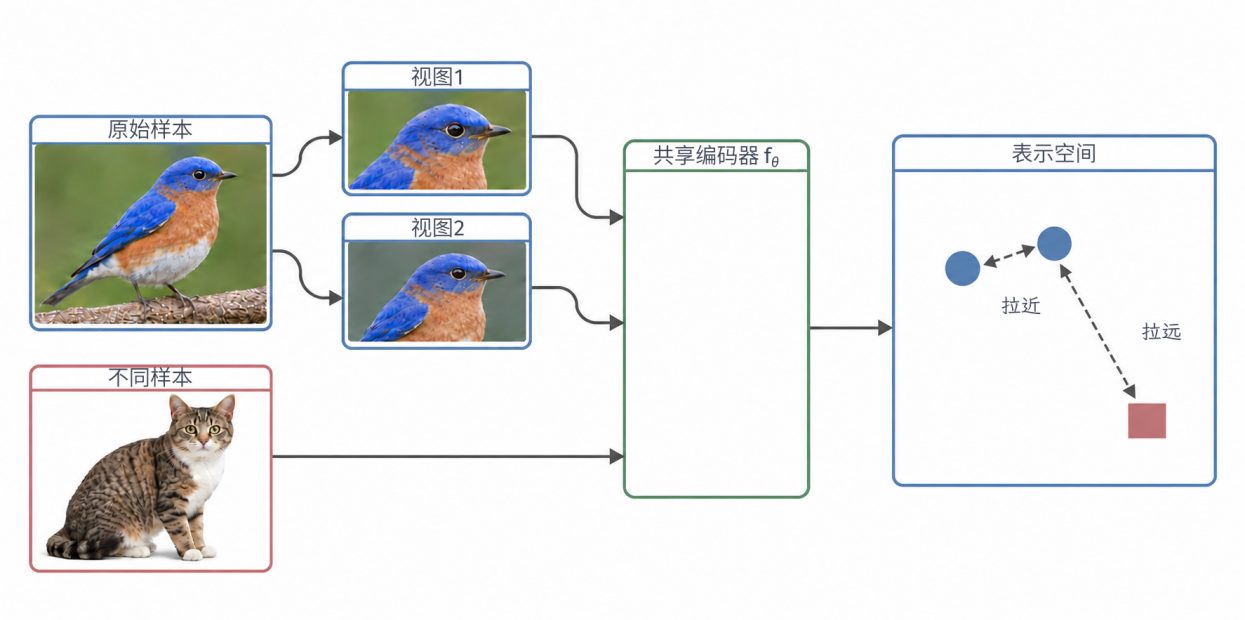


图 3.7　自监督对比学习的教学示意。同一幅鸟的原图分别经裁剪与颜色变化形成两个视图；它们与另一幅猫图的视图经共享参数的编码器得到表示。两个蓝色点表示同源视图的表示，红色点表示其他原图的对照；箭头只示意同源拉近与对照相对分离的训练目标。动物图元和表示位置均为教学构造，不是实测影像或表示分布。

匹配也可以由类别标签定义，形成监督式对比学习[17]。还可匹配图像和描述它的文字。因此，对比限定目标的构造，自监督限定信号来源。SimCLR兼具两者，掩码预测则使用自监督来源而未采用对比目标。

这些关系还需服从任务含义。裁剪若改变内容，同源视图未必仍适合匹配；不同原图若拍摄语义相近对象，把它们一律作为负对照可能妨碍后续分类。采用对比目标前，需要检查哪些差别应保留、哪些变化应忽略。

[17] P. Khosla, P. Teterwak, C. Wang, A. Sarna, Y. Tian, P. Isola, A. Maschinot, C. Liu, D. Krishnan, *Supervised Contrastive Learning* In Advances in Neural Information Processing Systems 33, 2020, pp. 18661–18673

### 3.4.5 主动学习

若能补充标签但预算有限，我们还需决定为哪些样本补充标签。**主动学习**（active learning）根据当前知识选择样本，再请人或其他可靠来源提供答

案，希望有限查询补足覆盖或纠正错误。这里的选择对象是新增标签的获取位置。

池式设定需要未标注样本池、当前模型、可回答查询的来源及预算。相关输入尚未收集或回答来源不可靠时，主动选样本身不能补齐缺失信息。因此，查询策略的作用以这些资源可用为前提。

Gal 等人的 MNIST 研究从 20 张类别均衡的标注图开始，每轮查询 10 张，再学习并与随机选样等准则比较[18]。基准中的查询只是揭示已保存但对模型隐藏的标签，未必由现场标注者实时作答；应用中则可由医生、工程师或普通标注者提供。图 3.8展示新标签进入模型之后，下一轮选择随知识变化的循环。

[18] Y. Gal, R. Islam, Z. Ghahramani, *Deep Bayesian Active Learning with Image Data* In Proceedings of the 34th International Conference on Machine Learning, 2017, pp. 1183–1192

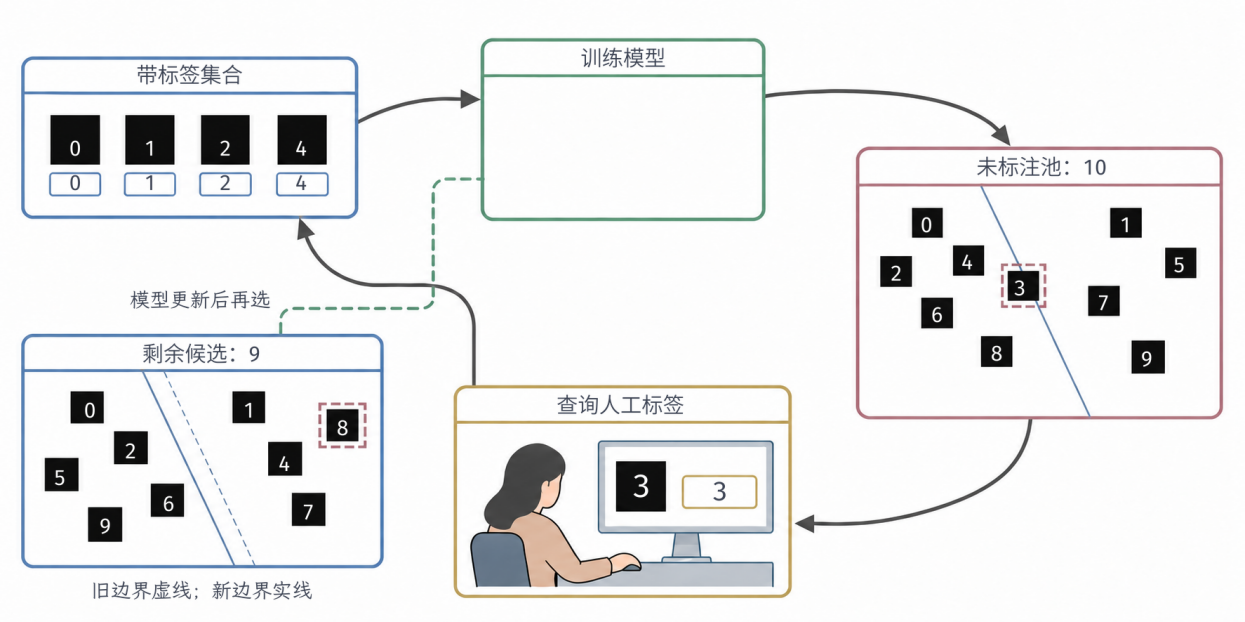


图 3.8 池式主动学习的教学示意。蓝色直线表示当前模型的决策边界，红色虚线方框标出本轮查询的数字 3。标注者返回标签后，样本并入带标签集合，用于重训模型，未标注池由 10 个候选减为 9 个。左下方的虚线保留更新前的边界，实线表示更新后的边界；虚线方框标出的数字 8 是下一轮查询对象。查询预算限制循环。数字字形、二维位置和边界均为教学构造，不表示实测分布或选样收益；数字样本的外观不等同于供模型使用的类别标签。

不确定性只是选样的一项依据。严重模糊的数字虽让模型犹豫，得到标签却未必能提供可推广规律；不断查询几乎相同的写法，也可能重复信息。我们还要检查覆盖与多样性、回答可靠性，以及各样本的标注成本，才能判断新增标签是否值得。

主动与半监督可以共同用于数字识别：一部分图被选中请求真实标签，其余图通过伪标签或一致性参与训练。查询解决预算怎样分配，半监督解决剩余无标签输入怎样利用，二者承担不同步骤。

主动学习只决定优先询问的样本。答案能否使用，还取决于标注任务和判定规范、直接作答或候选比较等交互方式、标注者能力、复核及预算分配。这些条件同属人工知识获取，需要在查询策略之外说明。

选择与反馈的循环并不自动构成强化学习。本例查询返回图片标签，评价是在给定标注预算下，独立评价集上的数字分类准确率；强化学习以奖励评价行动后果及累计回报。当然，多轮查询也可再建模为序贯决策，并用强化学习寻找策略，但这属于额外实现选择。

### 3.4.6 标签利用方式的比较

用同一批少量有标签的花卉照片比较：半监督围绕花卉分类，同时利用标签和未标注输入；自监督先由照片构造目标，学习表示，后续还需类别标签或其他信息规定识别对象。前者利用现有两类数据完成目标任务，后者先解决额外标签缺失时的信号来源。

专家只能提供粗判断，或规则提供有误差标签时，弱监督关注怎样使用和修正这些信号；专家能可靠回答而预算有限时，主动学习关注先询问哪些照片。二者分别限定监督质量与获取过程，节省标注这一共同目的不足以使它们等同。

对比则规定怎样利用样本关系，同源视图或类别标签均可产生匹配目标。因此，它可以与自监督或监督重叠；半监督也可归入广义弱监督。表 3.2按资源、方式和条件汇总，帮助判断方案适用性，而非要求系统只能选一个名称。

| 范式或方法 | 可以利用的资源 | 减少标签依赖的方式 | 需要检查的条件 |
|---|---|---|---|
| 半监督学习 | 少量标签与无标签数据 | 让无标签样本也参与目标任务学习 | 数据结构与目标类别是否相符 |
| 自监督学习 | 原始内容及其关系 | 从数据中构造训练目标 | 所学规律是否对实际任务有用 |
| 弱监督学习 | 粗标签、噪声标签或规则 | 接受成本较低的不完善监督 | 标签误差及不同来源的依赖 |
| 对比学习 | 视图、配对关系或类别标签 | 用匹配关系学习可复用表示 | 匹配依据是否可靠；也可使用标签 |
| 主动学习 | 可查询的样本与标注来源 | 优先为有价值的样本获取标签 | 查询收益、样本覆盖与标注成本 |

表 3.2 围绕有限标注比较知识的获取与使用。减少人工任务标签并不等于减少全部训练成本，也不保证这些方法在任意数据上都能提高效果。

同一样本可能得到多来源判断，融合前首先要确认对象、语义及粒度是否对齐，再评估覆盖、偏差和依赖。结果可保留单标签、概率、候选集合或弃权，而不必强行确定答案；一致来源也可能共享错误。标签、关系和约束若无法化为同一语义下的判断，就应保留含义分别参与训练，不能直接投票。

融合后仍需质量处理。我们用独立依据及有代表性的审计样本区分已确认错误、复核线索和信息不足，定位来源或构造环节，再修正、独立验证并记录版本。任务答案可检查正确性，关系与表示目标还要检查构造条

件及下游用途。评价标准跟随知识的含义，这些步骤才使候选依据进入可用训练流程。

## 3.5 知识的演进与迁移

经验利用还会遇到时间与任务变化。道路识别从白天转到夜间，或从物体类别扩展到距离估计，都会要求检查已有知识能否复用、新旧能力应怎样联系。即使数据与任务未明显改变，也可能需要修正事实或组合分别训练的模型。因此，知识演进不限于分布变化后的重新训练。

数据变化可涉及拍摄条件、样本组成及输入与目标的统计关系；从同一分布换一批样本，不代表分布改变。任务变化涉及输出、类别范围或评价目标，例如从识别转向距离估计。同一数据可服务不同任务，同一任务也可面对不同分布，需要分开描述。

知识可以承载在样本和外部记忆、表示与关系、预测规则、参数、模块或学习策略中。这些对象以不同方式影响后续学习和预测。参数变化不能直接证明某条事实已正确修改，外部记录存在也不能证明模型会使用；知识载体、能力和事实含义应分别检查。

持续学习关注经验随时间累积，多任务关注跨任务共享，迁移关注来源对目标的帮助，元学习关注怎样改进后续学习。比较时还需说明任务组织、历史访问和评价要求，不能只按数据或任务是否变化分类。下面先讨论新经验到来时怎样保留所需旧能力。

这四种范式为第四卷“范式”的“知识的演进与迁移”部分提供入口。后续会研究复用是否值得、选择哪些知识、怎样更新维护及整合能力，再研究迁移与共享的实际收益。更新保留、共同训练和目标适应可能交叉，也会使用共同的选择、整合与评价方法。

### 3.5.1 持续学习

未来经验不能一次收齐：拍摄条件、用户兴趣或类别范围可能陆续变化。**持续学习**（continual learning）要求按顺序吸收新经验，同时保留任务仍需要的旧能力。适应与保留必须一起进入评价。

同一参数可能同时支持新旧能力，按新数据更新就可能破坏旧任务。固定旧评价集与指标后，若更新后指标恶化，例如旧类别识别的准确率降低，我们称之为旧能力遗忘；严重时称为**灾难性遗忘**（catastrophic forgetting）。所以检查新内容学会以后，还要回到旧内容，而不能只报告最新阶段成绩。

图像类别可以分批到达，每阶段要求识别全部已见类别，且预测时不提示图片来自哪个阶段，这就是**类别增量学习**（class-incremental learning）。iCaRL 在 CIFAR-100 和 ImageNet 上逐步增加类别，并限制保存的旧样本

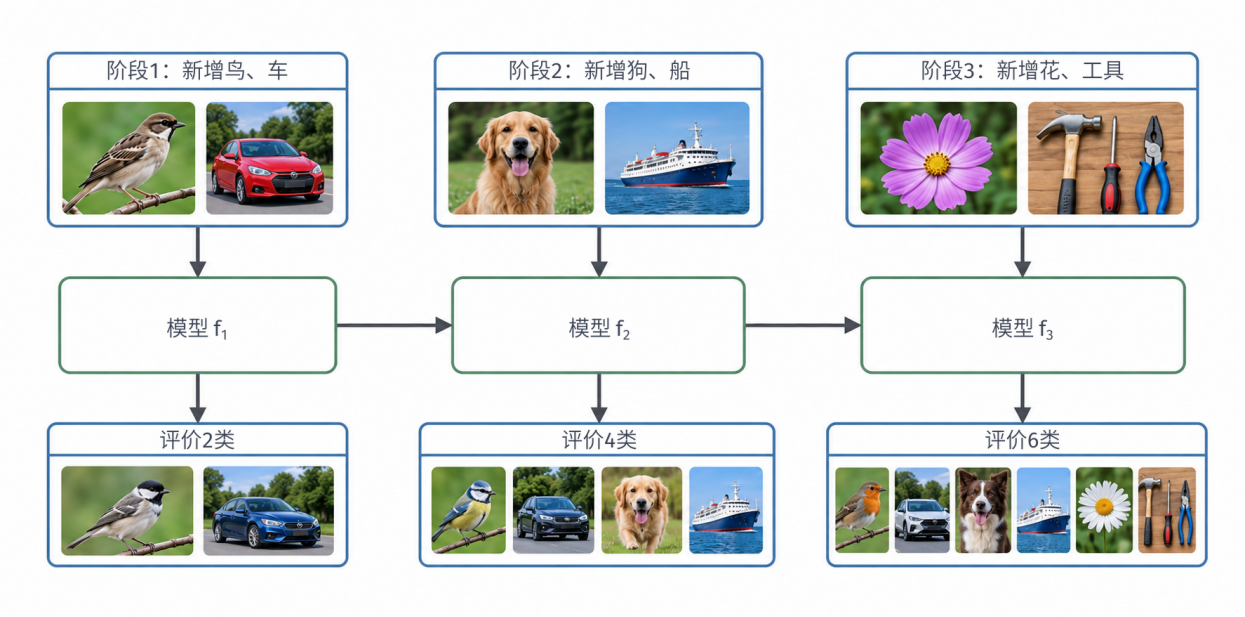


图 3.9 持续学习的类别增量过程。不同类别的图像按阶段到来；每个阶段都要学习新增类别，并在截至当前出现过的全部类别上检查能力。横向箭头串接各阶段的模型更新，下方评价范围依次覆盖 2、4、6 类，预测时不给阶段身份。样本图片为教学构造，模型框不对应精确记忆容量。

数[19]。图 3.9展示评价范围怎样扩大：每次既检查新增类别，也检查旧类别保留。

这种要求的难度依赖历史访问、任务边界提示和评价时间。全部历史数据可用时，可以重新训练；只能保留少量旧样本时，复习更受限制。持续学习也可处理传感器、兴趣或任务的连续变化，讨论时应先给出这些条件。

预测时若知道当前任务，可以选择相应输出，这构成**任务增量学习**（task-incremental learning）。若输出含义保持不变、输入分布陆续改变，且不给任务身份，则是典型**领域增量学习**（domain-incremental learning）。它们与类别增量构成常用比较设定[20]。分别改变提示、输出范围及分布条件。

白天与夜间都识别同一组交通标志，可以形成领域增量；陆续增加标志种类并在全部已见类别中选择，可以形成类别增量；先告知每次属于哪组识别任务，则更接近任务增量。三者都要按要求保留能力，但结果不能脱离提示和预测范围比较。若目标同时包含白天与夜间，仅夜间改善而白天失效就未满足要求。

更新维护的范围比持续学习更广，还包括修正过时事实、修改指定内容，或消除特定训练记录的影响。对象可以是参数、结构或外部记忆，不必以分布变化为前提。修改后需要分别验证目标内容、相关内容一致性、无关能力保留及后续可学性，并记录版本与恢复方式。

[19] S.-A. Rebuffi, A. Kolesnikov, G. Sperl, C. H. Lampert, *iCaRL: Incremental Classifier and Representation Learning* In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2017, pp. 5533–5542

[20] G. M. van de Ven, A. S. Tolias, *Three Scenarios for Continual Learning* In arXiv preprint arXiv:1904.07734, 2019

### 3.5.2 多任务学习

若相关任务的数据能在训练中共同访问，我们可以让它们相互提供信息。街景识别与距离估计都可能需要物体边界，**多任务学习**（multi-task learning）通过共享表示或其他知识共同学习各项目标[21]。一个任务的反馈由此有机会帮助另一个任务；并行运行彼此不联系的模型，并不会产生这一共享机制。

[21] R. Caruana, *Multitask Learning* In Machine Learning, 1997, vol. 28, pp. 41–75

街景中的**语义分割**（semantic segmentation）逐像素预测道路、车辆、建筑等类别，**深度估计**（depth estimation）估计像素所对应物体的距离。Kendall 等人还加入区分物体个体的**实例分割**（instance segmentation），研究怎样平衡不同任务的反馈[22]。

[22] A. Kendall, Y. Gal, R. Cipolla, *Multi-Task Learning Using Uncertainty to Weigh Losses for Scene Geometry and Semantics* In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2018, pp. 7482–7491

图 3.10仅展示语义与深度两项：同图经过共享模块，再分成两路预测，各路与自身标注比较，反馈共同调整共享部分。边界信息可能因此被两项任务复用，各自的预测要求却仍需保留。

任务集合可以固定不变，数据也可以预先收齐，多任务学习并不要求时间变化。各任务既可共享输入而使用不同标注，也可拥有各自数据集。定义所关注的是学习之间的联系，即一个任务的训练能影响另一任务。

多任务与持续学习的区别要看经验组织。训练期间能反复访问各任务数据，即使交替更新，仍可属于共同学习；经验顺序到来且历史无法完整访问时，则更突出持续学习的保留要求。任务数量本身无法区分二者。

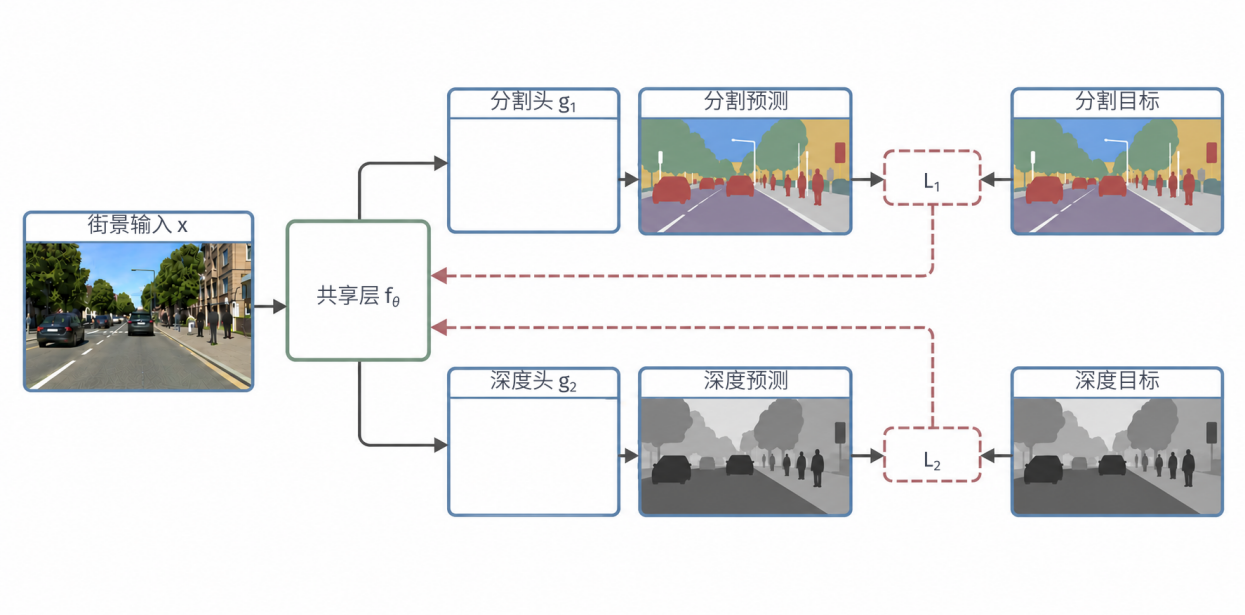


图 3.10 多任务学习的过程示意。同一街景及不同任务的标注共同影响共享表示，系统分别输出语义区域和远近关系；两个结果都是概念示意，不是论文实验的实际输出。

共享可能带来收益，也可能使一个任务的更新损害另一个任务；数据更多或更容易的任务还可能主导表示。我们因而要分别评价各任务，再决定任务分组、共享内容与结构、联合目标，以及样本、更新和计算资源的分配。单个汇总分数不能充分呈现任务干扰。

多任务从共同训练出发；已有模型或模块若先分别学成，再通过预测组合、连接、参数融合或蒸馏协作，则主要属于知识整合。它处理的是已有能力怎样进入新的计算过程，与前述候选标签等训练依据的融合对象不同。

### 3.5.3 迁移学习

已有相关经验还可以帮助一个目标问题。**迁移学习**（transfer learning）区分来源与目标，把来源学到的表示、参数等用于目标，减少从头学习的需求。它可帮助标签有限的任务，也可用于加快学习或适应分布变化，但首先要判断哪些来源知识仍对目标有用。

教学中的花卉模型可以先复用 ImageNet 训练所得图像表示，再用较少花卉标签学习类别。来源提供边缘、纹理及形状等基础，目标标签仍负责规定花卉之间的重要差异。图 3.11的箭头指明已有表示或参数进入目标学习，目标学习由此从已有图像经验出发。这里的花卉过程是教学情景。

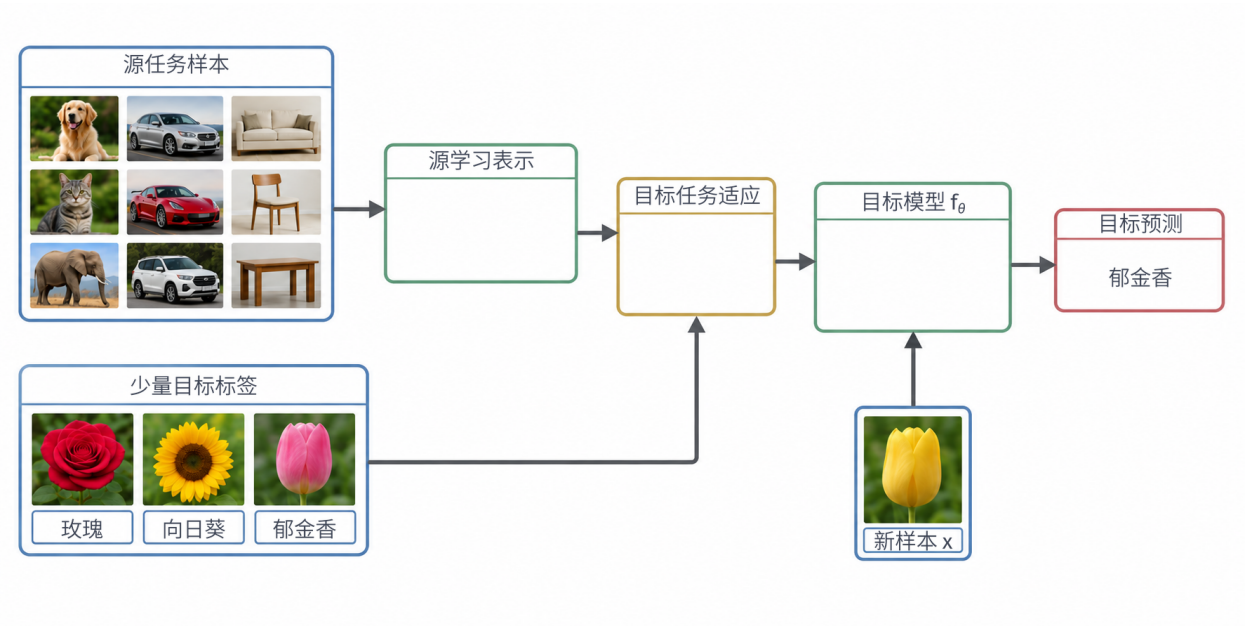


图 3.11 迁移学习的过程示意。通用图像任务形成可复用的表示，目标任务再用少量花卉标签调整这些知识，最后识别新的花卉照片；来源知识与目标数据共同决定结果。

通用来源不会自动规定花卉分类标准。边缘、颜色和纹理可能共用，但足以区分汽车与动物的特征，未必区分外形近似的两种花。目标标签要使模型进一步关注相应差异。

图像网络早期层常提取边缘、颜色与局部纹理，较后层再形成与训练任务相关的组合。Yosinski 等人的研究中，高层特征通常更依赖原任务；在论文比较的任务划分中，来源与目标差异更大时，冻结特征后的目标分类准确率相对于直接在目标上训练的基线下降得更多[23]。这一结果须按固定目标评价集及指标理解，不能外推为高层一概不可复用。保留或调整哪些层，仍要针对目标检验。

[23] J. Yosinski, J. Clune, Y. Bengio, H. Lipson, *How Transferable Are Features in Deep Neural Networks?* In Advances in Neural Information Processing Systems 27, 2014, pp. 3320–3328

以来源参数为起点，继续用目标数据调整，称为**微调**（fine-tuning）；也可以冻结已有表示，只训练目标输出模块。两者是复用方式，选择依据包括目标数据量、任务差异及允许修改的范围。

信息访问还会限制这些方式。来源可能开放数据、参数、中间表示或模块，也可能只允许查询输出；目标可能提供标签、无标签输入、描述或随后反馈。我们还需记录训练、模型选择及部署各阶段可以使用哪些信息，相同方法名称不能抹去这些条件。

迁移主要补充先前知识，主动学习主要决定获取哪些新标签。花卉系统可先复用图像表示，再查询尚需确认的照片。组合是否有帮助，要同时检查来源相关性及新增标签是否补足目标缺口。

来源到目标不要求数据与任务同时变化。通用分类转到花卉改变类别范围；白天到夜间可以保持类别而改变输入分布。描述迁移时，应逐项说明差异，而非仅称为换了一批数据。

街景中，若深度表示帮助语义分割且最终只关注后者，比较突出迁移；若两项监督共同训练共享表示，并分别评价，则突出多任务。二者可以重叠，迁移也可借共同训练实现，训练先后并非充分判据。持续学习还需按要求保留旧能力，一次迁移则可能只要求目标表现。

在相同目标评价数据和可用目标信息下，若复用来源知识的指标劣于从头学习的基线，例如目标分类准确率更低，称为**负迁移**（negative transfer）。判断必须在目标任务上比较，来源规模和来源成绩不能替代证据。复用决策还需比较标签或反馈需求，以及准备、适应、推理与存储成本；效果有益也不保证每种成本口径都更合适。

任务不变而拍摄环境改变时，还要说明目标信息何时可用。本书用**域**（domain，也称领域）描述输入空间及其数据分布，**源域**（source domain）提供已有知识，**目标域**（target domain）是希望模型有效工作的环境。白天、雨天和夜间可呈现不同统计规律；域不由数据集名称唯一决定，同一数据集可含多种环境。

夜间图片可提前收集时，我们可以利用它们适应白天模型。**领域自适应**（domain adaptation，也称领域适应）据可用目标数据处理分布差异；有目标标签时属于有监督设定，源有标签而目标只有输入时属于**无监督领域自适应**（unsupervised domain adaptation）。域对抗方法尝试保留源分类

能力，同时让表示难以区分来源，以辅助迁移[24]。无监督只限定目标标签，缩小表示差异也不自动保证目标正确。

部署环境尚未确定时，训练和选择阶段无法使用目标数据。**领域泛化**（domain generalization）只利用一个或多个源域，要求在未见目标域工作[25]。例如，以若干城市的白天、雨天图像准备模型，之后直接预测此前未接触的夜间输入。这比同分布新样本评价增加了环境差异，不能假定来源已覆盖未来变化。

这一限制也包括调参、停止时间和模型选择，不能提前借夜间数据作这些决定。可用来源留出域模拟变化；Gulrajani 与 Lopez-Paz 专门研究了选择方式对评价的影响[26]。目标数据在本章标准设定中只用于最终检验。预测当然要读取当前图像，但读取以输出，与利用它更新模型不同。

源域之间稳定的物体形状可能帮助减少背景依赖，但源间稳定并非任意目标稳定，增加源域也不必然改善目标。若未来输入或标签规律任意改变，原经验无法保证成功。领域泛化仍依赖来源与目标可利用的联系，第 9.3节将说明学习条件。

部署时可见目标输入，又提供了适应机会。**测试时适应**（test-time adaptation）按约定利用测试或部署数据更新参数或统计量，常见设定没有目标标签。Tent 用测试输入及预测更新部分参数，以降低预测分布的熵，使类别概率更集中[27]。但自信可能伴随错误，更新也可能强化错误。评价要规定输入可见范围、更新时序，以及跨样本是否保留状态。

表 3.3以目标信息的可用阶段对照。训练按领域泛化准备、部署继续适应时，系统同时涉及两套条件；报告应说明发生了更新，不能把适应结果计为固定模型的直接泛化。

[24] Y. Ganin, E. Ustinova, H. Ajakan, P. Germain, H. Larochelle, F. Laviolette, M. Marchand, V. Lempitsky, *Domain-Adversarial Training of Neural Networks* In Journal of Machine Learning Research, 2016, vol. 17, no. 59, pp. 1–35

[25] K. Muandet, D. Balduzzi, B. Schölkopf, *Domain Generalization via Invariant Feature Representation* In Proceedings of the 30th International Conference on Machine Learning, 2013, pp. 10–18

[26] I. Gulrajani, D. Lopez-Paz, *In Search of Lost Domain Generalization* In International Conference on Learning Representations, 2021

[27] D. Wang, E. Shelhamer, S. Liu, B. Olshausen, T. Darrell, *Tent: Fully Test-Time Adaptation by Entropy Minimization* In International Conference on Learning Representations, 2021

| 设定 | 可用的目标域信息 | 关键条件 |
|---|---|---|
| 有监督领域自适应 | 适应时已有目标域带标签样本 | 用目标监督调整模型，另留样本评价 |
| 无监督领域自适应 | 适应时已有目标域无标签输入 | 源域标签与目标域输入共同参与学习 |
| 领域泛化 | 训练及模型选择时均无目标域数据 | 本章标准设定在目标域直接预测，不更新模型 |
| 测试时适应 | 测试或部署时利用目标输入；常见设定无标签 | 按约定更新参数或统计量，并说明数据与时序限制 |

表 3.3　目标域数据的可用性区分领域自适应、领域泛化与测试时适应。前两行区分目标监督条件，最后一行强调适应发生的阶段；它们不是完全互斥的分类。

目标标签量构成另一项条件。花卉分类每类只给极少带标签例子时，本章称为**少样本学习**（few-shot learning）；不提供目标类别的带标签训练例子，而借助先前知识和类别描述等信息时，称为**零样本学习**（zero-shot learning）。它们限定目标资源，并不单独规定来源知识怎样获得与迁移。

类别文字要参与识别，模型需先建立图文联系。CLIP 共同学习图像与文本表示，让配套图文得分高于同批不匹配组合[28]。这沿用第 3.4.4节的关

[28] A. Radford, J. W. Kim, C. Hallacy, A. Ramesh, G. Goh, S. Agarwal, G. Sastry, A. Askell, P. Mishkin, J. Clark, G. Krueger, I. Sutskever, *Learning Transferable Visual Models from Natural Language Supervision* In Proceedings of the 38th International Conference on Machine Learning, 2021, pp. 8748–8763

系目标，但比较双方变成图像和描述，所得经验也包括视觉内容怎样对应文字。

使用时可把类别写为“a photo of a cat”（一张猫的照片）或“a photo of a dog”（一张狗的照片），比较新图与各描述的匹配得分，再选择最高者。目标分类不再需要新增带标签训练图，因而属于零样本分类。“零”只限定这部分数据，模型仍依赖已有图文经验，也不能据此断言预训练未包含相关概念。

零样本与领域泛化限制不同。前者在此限制目标类别的标签，后者限制目标域数据在训练及选择中的使用。新类别可以出现在已见环境，新环境也可以包含源域已有类别，所以二者需分别判断。

### 3.5.4 元学习

若系统反复识别新字符且每次只有几个例子，我们还可以提前练习怎样快速适应。不同小任务提供历史学习经历，适应后的表现再用于改进下一次学习，而不只是复用一个固定表示。

从一组任务的学习经历改进后续学习，称为**元学习**（meta-learning）。它可用于少样本适应，也可关注速度或稳健性[29]。“学习如何学习”概括的是跨任务经验的作用，实际系统仍需预先规定模型、目标和更新方式。

以反复学习新字符为例，我们可以让模型每次从同一组起始参数出发，用少量示例调整，再用同任务另一批样本检查预测损失。**模型无关元学习**（model-agnostic meta-learning, MAML）利用这些适应后的检查损失更新起始参数，以降低之后少样本适应后的预测损失[30]。评价对象由起点自身转向了从起点学习以后的结果。

MAML 的 Omniglot 实验把少数手写字符类别组成一项任务。每项任务从共同参数出发，以少量标签适应，再以同任务另一批样本检查新写法的识别；这些检查损失汇总后更新共同起点，随后继续练习其他任务。这一准备过程称为**元训练**（meta-training），反复优化的是后续适应效果。

图 3.12中，任务内检查样本虽未用于该次少量适应，却通过损失参与起点更新，仍属于元训练。最终评价则使用未参加元训练的新任务，字符实验中对应新类别，只考察少量新示例之后的学习效果。两类检查数据不能混用。

普通预训练也可迁移参数，差别在准备目标。把旧字符类别合并做监督分类，反馈来自来源识别误差；MAML 把数据组织为少样本任务，先适应再检查，反馈来自适应后对该任务新样本的表现。即使两者使用大量旧字符，一个起点为来源识别优化，另一个为少量示例后的学习效果优化。

使用时，两者均可能载入参数再作少量调整，因此要追溯准备阶段才看得出区别。迁移关注来源如何帮助目标，元学习关注历史任务怎样改进学

[29] T. M. Hospedales, A. Antoniou, P. Micaelli, A. J. Storkey, *Meta-Learning in Neural Networks: A Survey* In IEEE Transactions on Pattern Analysis and Machine Intelligence, 2022, vol. 44, no. 9, pp. 5149–5169

[30] C. Finn, P. Abbeel, S. Levine, *Model-Agnostic Meta-Learning for Fast Adaptation of Deep Networks* In Proceedings of the 34th International Conference on Machine Learning, 2017, pp. 1126–1135

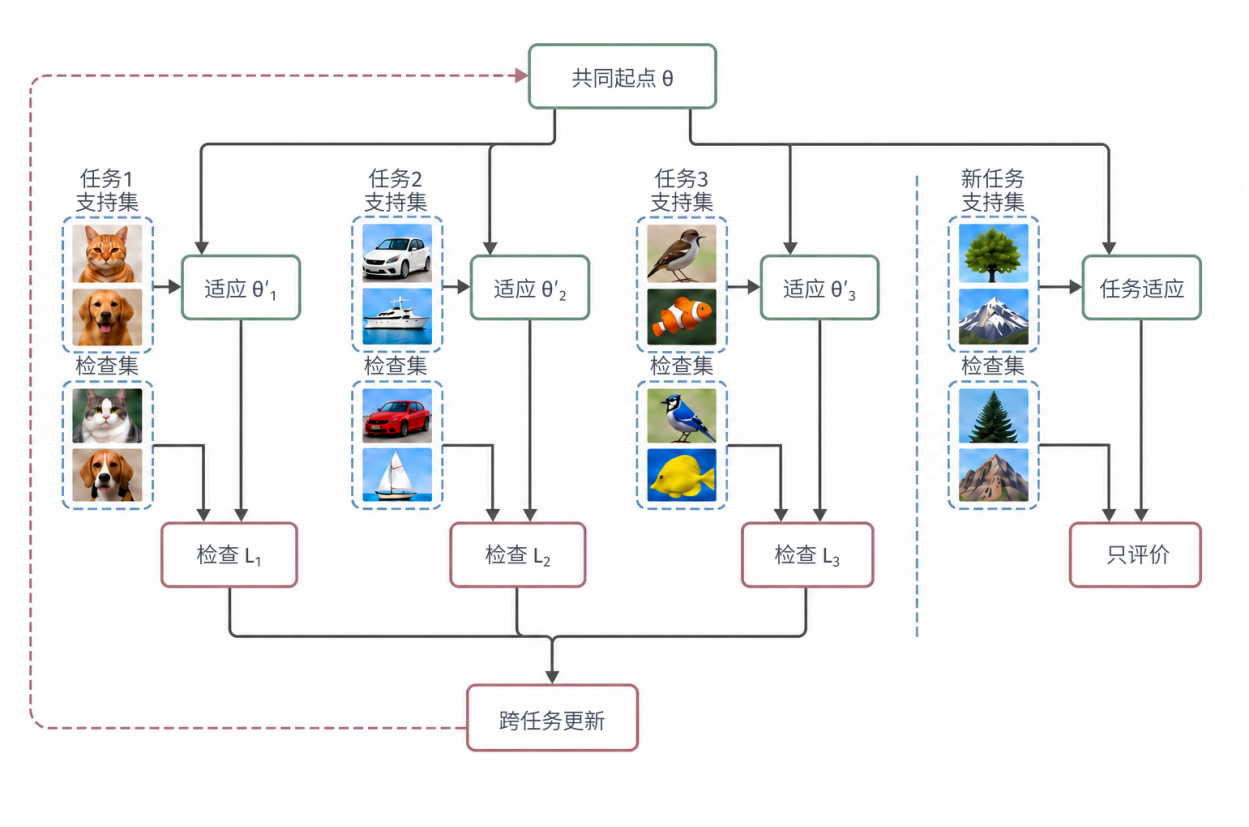


图 3.12 任务内适应与跨任务更新。元训练任务从共同起点 $\theta$ 出发，用任务内适应样本得到参数 $\theta'_\tau$，再汇总另一批检查样本上的损失 $L_\tau$ 来更新起点；两批样本都参与元训练。未参加元训练的新任务只用少量适应样本调整参数，最终检查评分不回传共同起点。任务与图像样本为教学构造，不是 Omniglot 原始样本。

习过程；元学习起点用于新任务也可视为迁移。上述比较仅限定普通监督预训练和 MAML，不能把两类范式视为互斥。

少样本只是数据条件，普通迁移等方法同样可以处理[31]。元学习的收益还依赖练习任务与未来任务的联系，差异过大时适应方式可能失效。新任务只给几个例子，也不意味着准备阶段只学过几条数据，它仍可能需要许多历史任务。

例子也可以只进入输入。给语言模型几条评论及其情感标签，再接新评论，让它作答而不更新参数，称为**上下文学习**（in-context learning）。GPT-3 的少样本实验采用这一方式[32]。因此，使用新示例时要区分输入上下文与参数更新；能利用示例作答本身，也不足以证明曾接受任务适应目标的元训练。

多个训练任务也不足以确定元学习。街景多任务要做好已有分割与深度任务，少样本元学习借历史任务练习适应，再在未见任务上评价。任务承担的用途和最终评价对象，比任务数更能说明设定。

[31] Y. Wang, Q. Yao, J. T. Kwok, L. M. Ni, *Generalizing from a Few Examples: A Survey on Few-Shot Learning* In ACM Computing Surveys, 2020, vol. 53, no. 3, pp. 1–34

[32] T. B. Brown, B. Mann, N. Ryder, M. Subbiah, J. Kaplan, P. Dhariwal, A. Neelakantan, P. Shyam, G. Sastry, A. Askell, S. Agarwal, A. Herbert-Voss, G. Krueger, T. Henighan, R. Child, A. Ramesh, D. M. Ziegler, J. Wu, C. Winter, C. Hesse, M. Chen, E. Sigler, M. Litwin, S. Gray, B. Chess, J. Clark, C. Berner, S. McCandlish, A. Radford, I. Sutskever, D. Amodei, *Language Models Are Few-Shot Learners* In Advances in Neural Information Processing Systems 33, 2020, pp. 1877–1901

### 3.5.5 数据与任务变化下的比较

表 3.4按数据、任务组织及评价汇总四种范式。多任务可以固定任务集合，持续学习可以只面对同任务分布变化，迁移和元学习都可处理新任务；后者还需追溯准备阶段是否改进学习过程。变化的时间、知识服务的对象及能力要求，应与变化本身一起报告。

| 范式 | 数据怎样变化 | 任务怎样组织 | 主要评价要求 |
|---|---|---|---|
| 持续学习 | 经验顺序到来，分布可能变化；旧数据访问常受限 | 任务可以不变，也可增加类别或依次出现新任务 | 学习新内容，同时保留所需旧能力 |
| 多任务学习 | 各任务可共享输入，也可使用不同数据集；不要求随时间变化 | 一组相关任务共同学习，任务集合可以固定 | 分别检查各任务表现与共享带来的影响 |
| 迁移学习 | 来源与目标的分布可以不同 | 区分来源与目标；目标任务可相同或不同 | 来源知识是否帮助目标任务 |
| 元学习 | 用训练任务积累学习经验，再以新任务数据考察适应 | 跨任务改进学习过程；本节以少样本适应为例 | 在给定适应数据和预算下学得怎样 |

表 3.4 从数据、任务及评价要求比较知识的演进与迁移。各行描述本节的典型设定，不是由“变或不变”唯一确定的互斥类别。

道路情景可统一比较这些要求。只检查白天知识能否帮助夜间识别，突出迁移；顺序接触环境且保留白天能力，加入持续学习要求；共同训练物体识别和距离估计，体现多任务；用历史场景练习少量示例适应，再在新场景检验，体现这里的元学习。新数据或多个任务可以出现在各设定中，知识组织与评价要求才进一步区分它们。

跨域问题还要按信息时机细分：夜间数据提前参与学习是领域自适应，训练及选择均不可见目标而直接预测是领域泛化，部署后以目标输入更新是测试时适应。除了变化内容，我们必须说明哪些信息在什么时候可用。

这些方式可以沿时间或任务相互连接。多任务表示可成为迁移起点，元学习的适应方式可用于连续任务。组合是否可行，还要检查所需数据当前能否访问，以及评价是否覆盖真正要取得和保留的能力。

评价因而不能只剩当前任务平均分。目标适应要报告效果与代价，持续更新要检查新知识、历史能力及后续可学性，指定修改和能力整合还需检查修改范围、来源能力及组合结果。人工、计算、存储和维护成本也应分别呈现，无换算依据时不宜混为一个数。

## 3.6 其他范式

反馈及目标确定以后，经验还可能逐条到来，或分散于不同设备。前者限制预测和更新时序，后者限制数据存放及协作方式。本节以在线和联邦学习说明这些发生条件，它们可以附加到前述范式上。

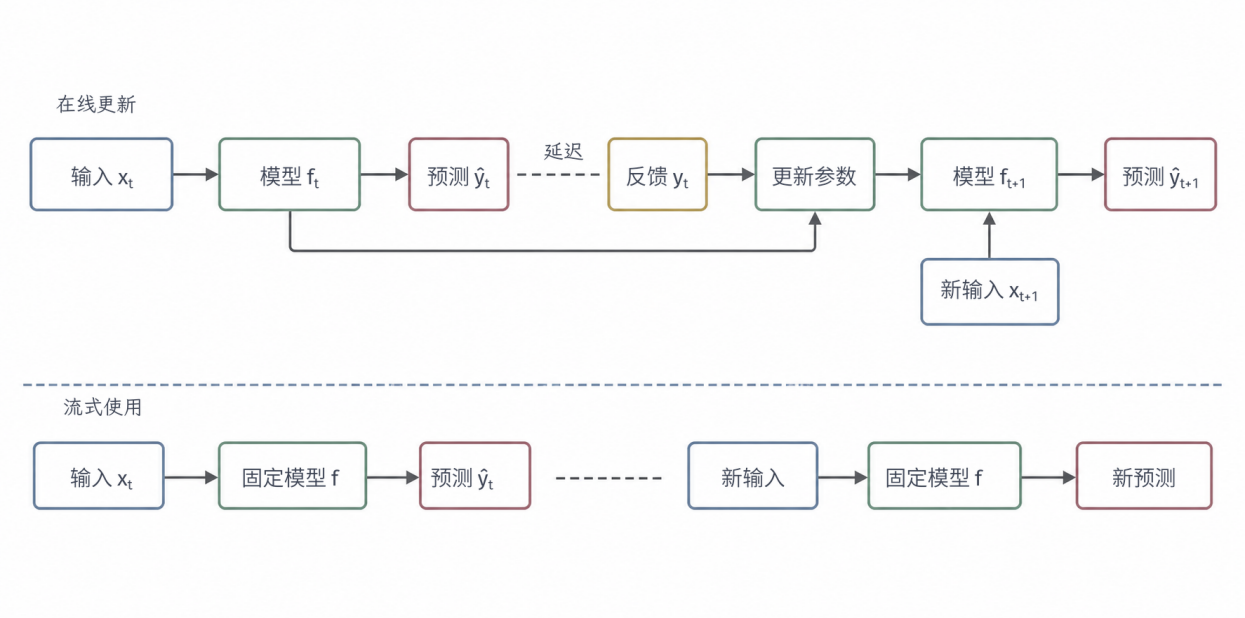


图 3.13 在线学习先用当前模型预测并保存此时尚未看到答案的结果，反馈可以延迟或按小批次到达，随后更新只作用于后续输入。下方对照只用固定参数持续响应的实时预测；请求持续到来本身不构成在线学习。

第四卷因此不为两者各设并列部分：在线时序进入交互或更新问题，联邦组织进入相应协作设定，工程实现继续由系统卷展开。

### 3.6.1 在线学习

经验持续到来时，学习者可以先用当前模型预测或决策，取得后续反馈再更新，然后处理新输入，这一时序称为**在线学习**（online learning）。相对的**批量学习**（batch learning）先对给定一批数据训练，再使用所得模型。区别在于经验进入更新的安排。

广告系统先根据内容与展示场景预测点击，之后观察点击结果并更新，提供了实际案例[33]。结果给出监督目标，在线规定其到达与使用时序；反馈可延迟，更新也可按小批次进行。联网或实时响应本身并不构成在线学习，若新反馈从不改变模型，系统只是持续预测。

图 3.13对照反馈更新与固定参数预测。评价应保存尚未获得反馈时的输出，随后更新才作用于后续输入。

在线与持续学习可以重叠，但各自限定不同条件。同分布样本也可依次预测和更新，在线并不要求任务变化或专门保留旧任务；持续学习关注长期适应与保留，也可按批次阶段更新。若系统逐次学习反馈且检验旧能力，就同时满足两种描述。

随时间改变的数据统计规律称为**分布漂移**（distribution drift）。其中**概念漂移**（concept drift）在本书专指给定输入后的目标规律变化，例如同样

[33] H. B. McMahan, G. Holt, D. Sculley, M. Young, D. Ebner, J. Grady, L. Nie, T. Phillips, E. Davydov, D. Golovin, S. Chikkerur, D. Liu, M. Wattenberg, A. M. Hrafnkelsson, T. Boulos, J. Kubica, *Ad Click Prediction: A View from the Trenches* In Proceedings of the 19th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 2013, pp. 1222–1230

广告与用户特征不再产生原有点击倾向；常见用户或广告比例改变则属于输入或协变量漂移。两者可并存，却有不同识别和调整条件，可能需要检测或改变历史经验权重[34]。在线只提供利用新反馈的时序，不能保证克服漂移，还受反馈延迟和样本不足限制。第 9.1.2节将形式化区分变化部分。

在线评价必须遵循真实信息顺序。先保存未见答案时的预测，反馈到达后再更新；若重算已经用于更新的样本，就不能还原当时表现。反馈延迟、数据保留量及更新预算也要报告，它们规定模型何时、凭多少经验改变。

[34] A. Bifet, R. Gavaldà, *Learning from Time-Changing Data with Adaptive Windowing* In Proceedings of the 2007 SIAM International Conference on Data Mining, 2007, pp. 443–448

### 3.6.2 联邦学习

手机键盘需要多样用词经验，但单台设备只有部分记录，原文本又不便集中。这里的困难是共同利用分散经验，而未必是总体样本数不足。我们需要一种保留本地数据的协作安排。

**联邦学习**（federated learning）让设备或机构保留本地数据，通过交换模型相关信息共同训练。手机键盘研究在设备端学习下一词，再汇总本地结果改善共享预测[35]。下一词目标由原文本构造，属于自监督来源；联邦则规定各地经验如何协作，二者限定不同方面。

中心协调的一轮先下发共享模型，各设备从它出发用本地数据训练，再上传所得参数。**联邦平均**（federated averaging, FedAvg）以样本量加权汇总[36]。令本轮参与集合为 $I_t$，第 $i$ 方数据为 $D_i$，$n_i = |D_i|$，并要求参与方的总样本量大于零。样本量及加权参数写为

$$n = \sum_{i \in I_t} n_i, \qquad \theta^{(t+1)} = \sum_{i \in I_t} \frac{n_i}{n} \theta_i^{(t+1)}. \tag{3.1}$$

$\theta_i^{(t+1)}$ 表示从 $\theta^{(t)}$ 出发完成本地训练的参数，所以样本多的参与方获得更大权重。公式使用训练后参数，更新也可另表示为改变量；改用其他权重则需说明。图 3.14展示下发、本地学习和汇总的循环。

[35] A. Hard, K. Rao, R. Mathews, S. Ramaswamy, F. Beaufays, S. Augenstein, H. Eichner, C. Kiddon, D. Ramage, *Federated Learning for Mobile Keyboard Prediction* In arXiv preprint arXiv:1811.03604, 2018

[36] H. B. McMahan, E. Moore, D. Ramage, S. Hampson, B. Agüera y Arcas, *Communication-Efficient Learning of Deep Networks from Decentralized Data* In Proceedings of the 20th International Conference on Artificial Intelligence and Statistics, 2017, pp. 1273–1282

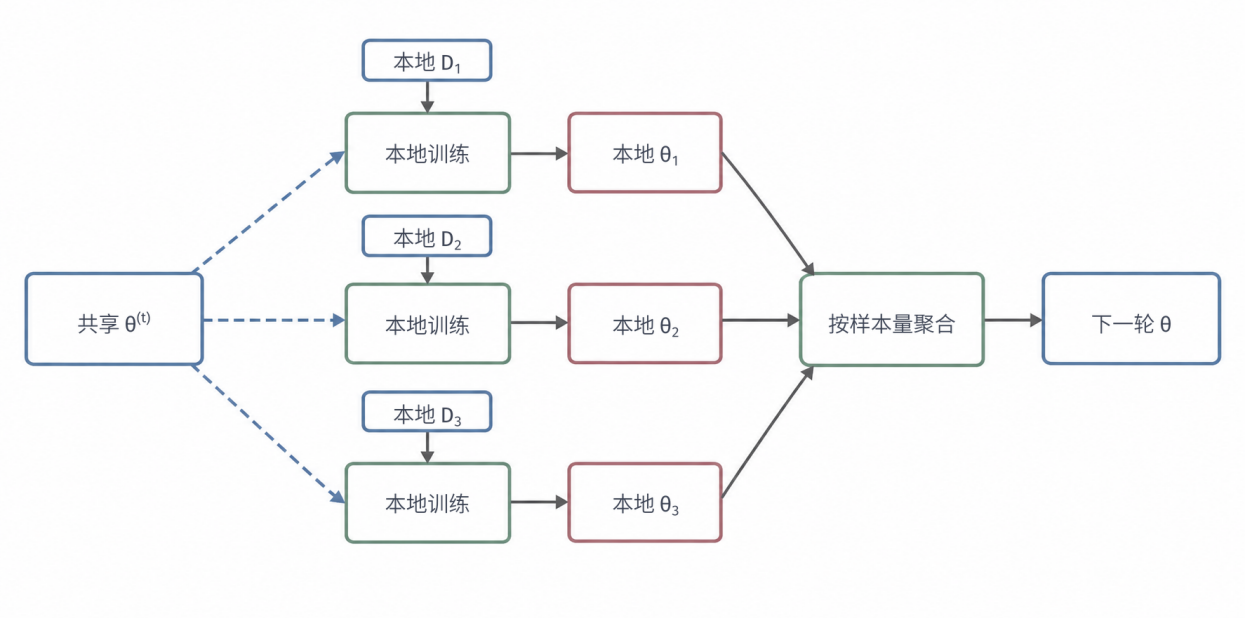


图 3.14 中心协调式联邦学习的一轮通信。协调方向三个示意参与方下发同一组共享参数 $\theta^{(t)}$；各方使用自己的本地记录集 $D_i$ 训练，得到本地参数 $\theta_i^{(t+1)}$ 并上传。协调方按正文所述的样本量权重形成下一版本 $\theta^{(t+1)}$，下一轮再统一下发。参与方数量为教学示意；原始记录留在本地，但模型更新仍可能泄露信息，联邦组织方式本身不提供隐私保证。

协作会遇到数据量、算力和在线状态的差异，也要承担反复下发及上传的通信成本。原记录留在本地，更新仍可能泄露信息，隐私还需额外机制，例如限制单设备更新的可见性。聚合、通信及部署由第六卷“系统”的“机器学习系统”部分展开，隐私机制由第3部分讨论。

共享模型也不一定适合每个用户。设备可迁移共享知识以适应本地，也可用多任务组织保留参与方差异；习惯沿时间改变时，还需检查持续学习。分散协作、个体适应与旧能力保留因而可能共同构成一项系统任务。

## 3.7 范式的组合

范式分别限定反馈、标签利用、复用及时序环境，同一系统可以跨阶段组合，也可以在同阶段使用多种信号。说明组合时，应逐步追踪数据、目标和反馈，交代哪些知识传给下一步，才看得出每种设定承担的职责。

自监督文本预训练之后用任务标签监督学习，形成分阶段组合：前者积累表示，后者调整到分类、问答等用途。半监督则在同一目标任务中共同使用标签与未标注输入，还可另加自监督目标。二者虽都有多种信号，却不能省略阶段和任务组织的差别。

2016 年 AlphaGo 先以专家棋谱的局面和落子训练策略网络，再用自我对弈的胜负继续改进[37]。传到后一阶段的是初始策略，反馈从专家动作变成对局结果。图 3.15只展示这条主线，完整系统还有价值网络与搜索等组

[37] D. Silver, A. Huang, C. J. Maddison, A. Guez, L. Sifre, G. van den Driessche, J. Schrittwieser, I. Antonoglou, V. Panneershelvam, M. Lanctot, S. Dieleman, D. Grewe, J. Nham, N. Kalchbrenner, I. Sutskever, T. Lillicrap, M. Leach, K. Kavukcuoglu, T. Graepel, D. Hassabis, *Mastering the Game of Go with Deep Neural Networks and Tree Search* In Nature, 2016, vol. 529, pp. 484–489

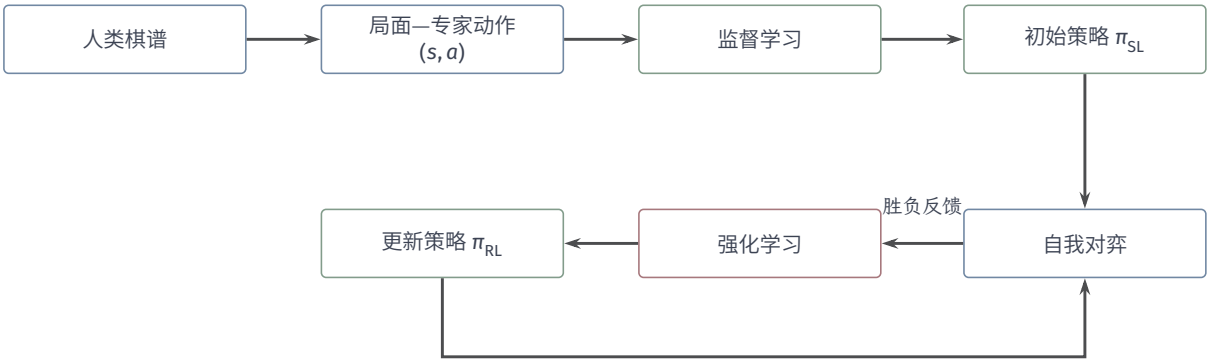


图 3.15 AlphaGo 学习主线的简化示意。人类棋谱为监督学习阶段提供局面与专家落子；得到初始策略后，自我对弈产生新棋局与胜负反馈，用于强化学习阶段。完整系统还包含价值网络与搜索等组件。

件。自我对弈使用奖励，属于强化学习，不能因“自我”二字将其归为自监督。

难以逐步打分时，人可能仍能比较两段行为。**偏好学习**（preference learning）利用这种相对判断；与强化学习组合时，可先请人选出更符合要求的片段，据此训练评价模型，再用所得奖励训练智能体。相关研究用于 Atari 和模拟机器人[38]。这里人提供行为好坏比较，未直接给每步动作；评价模型转成奖励，策略再依据奖励学习。

在假设的多机构花卉系统中，各机构保留照片，以联邦方式协作；本地无标签照片产生不同视图，通过自监督对比目标学习表示。联邦规定协作，自监督规定匹配来源，对比规定目标构造。这些描述可以共同成立，却不能互相替代。

系统还可主动查询部分专家标签，再结合剩余未标注照片作半监督训练；通用表示可迁移，新物种陆续加入时可检查持续学习。该情景用于解释组合，实际方案按需求选用环节即可。标签选择不替代目标学习，协作也不会自动消除来源差异、错误或遗忘。

[38] P. F. Christiano, J. Leike, T. B. Brown, M. Martic, S. Legg, D. Amodei, *Deep Reinforcement Learning from Human Preferences* In Advances in Neural Information Processing Systems 30, 2017, pp. 4299–4307

## 3.8 本章小结

本章从经验和反馈建立范式，而非仅按模型名称分类。任务规定目标，模型表达候选规律，范式组织学习依据。监督以输入和目标配对，无监督发现结构或分布，强化学习利用行动奖励改善决策。先追溯系统实际得到什么，再确定训练与评价的条件，才能说明学习怎样发生。

标签不足时，可以让未标注输入参与任务、由数据构造新目标、接受并处理较弱监督，或主动获取关键答案；对比学习则规定如何利用样本关系。

这些方式都依赖信号可靠且符合任务，减少人工标签不能自动保证能力。人工、规则、模型与数据提供的候选知识，还需对齐、融合、评估和修正。

经验演进后，持续学习强调顺序适应与保留，多任务强调共同共享，迁移强调来源对目标的帮助，元学习强调历史经历对后续学习的改进。在线与联邦分别限定更新时序和协作，目标信息的可用阶段又区分领域适应、泛化与测试时适应。组合时，应说明数据、反馈、任务关系与信息权限，再评价实际需获得和保留的能力。已有表示、参数、模块、记忆及学习策略怎样复用、更新或整合，也须分别检查效果和样本、计算、存储及维护代价，在明确预算下取舍。

**延伸阅读** 继续学习交互决策可读 Sutton 与 Barto 教材，标签质量及任务适应可分别参阅弱监督与元学习综述，联邦平均原始论文提供分散协作的具体入口[39,40,41,42]。结合第 2章，我们已有表示规律和利用经验的基本框架。第2部分将在给定经验、损失及比较标准下研究有限样本能否学到所需结果，第3部分检查其进入流程后的可靠性、鲁棒、公平、隐私、安全与处置要求。第四卷“范式”的“强化学习”部分、“知识的获取”部分及“知识的演进与迁移”部分再分别展开交互决策、训练依据和已有知识的利用，协作部署继续连接系统卷。

[39] R. S. Sutton, A. G. Barto, *Reinforcement Learning: An Introduction*, MIT Press, 2018, 2nd ed.

[40] Z.-H. Zhou, *A Brief Introduction to Weakly Supervised Learning* In National Science Review, 2018, vol. 5, no. 1, pp. 44–53

[41] T. M. Hospedales, A. Antoniou, P. Micaelli, A. J. Storkey, *Meta-Learning in Neural Networks: A Survey* In IEEE Transactions on Pattern Analysis and Machine Intelligence, 2022, vol. 44, no. 9, pp. 5149–5169

[42] H. B. McMahan, E. Moore, D. Ramage, S. Hampson, B. Agüera y Arcas, *Communication-Efficient Learning of Deep Networks from Decentralized Data* In Proceedings of the 20th International Conference on Artificial Intelligence and Statistics, 2017, pp. 1273–1282

第二部分

# 机器学习理论

Machine Learning Theory

# 阅读指引

分类器在一批训练邮件上答对很多次，仍可能只记住了这批输入；即使当前测试错误很少，换一批训练邮件也可能得到另一种规则。理论部分要说明，有限样本在什么条件下足以支持未来风险的判断。为此，我们同时规定观测怎样产生、允许哪些决策、如何计损失、算法能看到什么，以及成功要相对于哪个基准、在哪些随机变化中成立。

基础三章已经区分任务、模型、损失及反馈，第一卷则提供组合维度、集中不等式、随机复杂度、信息量、分布距离和优化条件。本部分把这些工具接到具体学习问题：候选空间怎样受控，样本怎样影响选解，经验评价怎样接近总体风险。涉及网络时，只建立推导所需的形式与条件；结构设计、反向传播和训练实践由第三卷展开。

《机器学习理论基础》以邮件二分类建立风险、PAC 标准和归纳偏置，说明拟合经验为何还缺少未来保证。随后两章改变候选数与标签结构，分别核对统计样本量、停机及计算资源。《一般学习的可学习性》把零一损失换为一般损失，从全类一致估计进一步转向算法稳定性。《深度学习的可学习性》追踪范数、初始梯度、训练选解和参数分布怎样接到风险。《迁移学习的可学习性》最后改变训练与评价分布，先判断目标预测能否由已有信息确定，再分析覆盖、共享机制和环境抽样如何支持有限样本保证。

六章复用共同的风险、概率量词和可测性约定，也逐步改变标签、损失、选解方式及数据来源。每次复用结论，都要重新核对这些对象和条件。所得保证约束的是允许问题中的风险或超额风险，还没有判断损失是否覆盖实际后果、比较基准是否可接受，也不能自动覆盖允许范围之外的环境。下一部分将这些使用问题逐项纳入评价与处置。

第 4 章

# 机器学习理论基础

我们用一批已标注的邮件训练垃圾邮件分类器，希望它也能判断新收到的邮件。训练邮件上的准确率只能检验分类器对这批输入的回答：能够利用共同规律的分类器与逐条记住训练数据的分类器，都可能在这里得到高分。要评价学习的结果，还须考察它们面对未见邮件时的错误。

把另一批邮件留作测试，可以估计当前分类器的错误率。学习算法的保证却还涉及另一层变化：重新抽取训练邮件后，算法可能选出不同的分类器。有限观测何时足以支持对未来错误率的判断，因而取决于数据怎样产生、算法怎样选择结果，以及我们允许多大的预测误差和训练失败概率。机器学习理论把这些关系写成明确条件，使一次测试的结果与重复训练的保证能够分别分析。

为分析这些条件，本章建立第 4–9章共用的学习问题框架。邮件二分类给出观测、假设和风险的具体含义，PAC 标准进一步约束算法在随机训练中的成功概率。记忆型反例与没有免费的午餐定理说明经验拟合的局限，风险分解和模型选择则解释限制假设空间的收益与代价。研究历史及当前前沿把这一框架放到更广的理论问题中，说明标签、损失、计算和环境变化为何需要分别讨论。

## 4.1 学习问题

在邮件分类中，一条训练记录包含邮件与标签，算法交付一个分类器，未来错误率用来评价它。在回归或聚类中，这些对象会改变；形式相同的风险界也就可能约束不同的结果。我们先把观测、候选决策、算法输出、计分方式与随机来源分开规定，再用二分类逐一具体化。这些职责由第 4–9章共享，对象的具体形式则随任务确定。

### 4.1.1 基本设定

先看算法收到的一条记录。邮件分类记录邮件及其类别，回归记录输入与数值响应，聚类记录待分组的对象。这些允许记录组成观测空间（observation

space），记为 $Z$；损失函数以其中的一条观测评价学习结果。指定 $Z$ 时也须确定记录的单位：单条记录、相互依赖的序列和整块环境数据可能包含不同信息，不能直接按同一种独立样本计数。

观测确定以后，还要给学习结果选定比较对象。全部阈值分类器、受限参数的回归函数或固定中心数的聚类方案，都可以组成一组候选决策，称为比较决策空间（comparison decision space），记为 $\mathcal{W}$。最低风险及超额风险相对于这组候选计算。另以算法输出空间（algorithm output space）$\mathcal{W}_{\text{out}}$ 记录算法能够交付的结果：直接选择候选时两者相同，组合候选或交付其他预测器时，输出范围可以更大。

评价决策还需要一条计分规则。**损失函数**（loss function）把决策与观测映射为代价，较小的损失表示较好的评价结果。至于算法会看到哪些观测、观测之间是否独立、未来损失对哪个总体取平均，则由数据来源及抽样机制规定。样本之外的标签、环境信息和辅助变量是否可见，也属于算法输入的一部分。下面将这些对象合在同一个形式设定中，分类与独立同分布只是它的具体取法。

**定义 4.1　学习问题的形式设定**　一个学习问题至少需要规定观测空间 $Z$、比较决策空间 $\mathcal{W}$、算法输出空间 $\mathcal{W}_{\text{out}}$、损失函数、允许的数据来源、抽样机制和算法可见的信息。

在 $Z$ 与 $\mathcal{W}^{+} = \mathcal{W} \cup \mathcal{W}_{\text{out}}$ 上约定相应的可测结构，并要求损失

$$\ell : \mathcal{W}^{+} \times Z \to \mathbb{R}$$

联合可测。

抽样机制规定算法所见观测 $S$ 的联合分布。内部随机数 $U$ 定义在另一个概率空间并独立于 $S$；学习算法 $A$ 是从允许输入到 $\mathcal{W}_{\text{out}}$ 的可测映射，输出 $A(S, U)$。确定性算法省略 $U$。

在这个设定里，$Z$ 与 $\ell$ 共同说明一条记录怎样为决策计分。$\mathcal{W}$ 提供比较基准，$\mathcal{W}_{\text{out}}$ 约束交付结果；因此，评价时比较哪些决策与训练时可以返回哪些决策，是两项分别指定的条件。

允许的数据来源限定保证覆盖的生成机制，通常不会作为已知信息交给算法。抽样机制进一步规定训练观测彼此之间、训练观测与评价观测之间的关系。独立随机数 $U$ 记录算法自身的随机选择，$A$ 则根据可见输入与 $U$ 产生决策。如此才能区分数据中的不确定性与算法引入的不确定性。

先取最常用的同分布基线。以 $\mathfrak{P}$ 收集允许来源，给定 $\mathcal{P} \in \mathfrak{P}$ 后，从中独立抽取 $n$ 条观测：

$$S = (z_1, \dots, z_n) \sim \mathcal{P}^{n}.$$

二分类、多分类与一般损失章节以此为起点。迁移学习另行规定源域、目标域、各样本量或环境层抽样，相应风险与概率也随之改变。各章沿用定义 4.1的对象职责，抽样关系则须在当地重新指定。

应用这一设定时，样本量必须随观测单位解释。独立记录的条数、序列的长度与环境块的个数，不能未经分析就相互替换。结论还须注明允许哪些分布：覆盖全部相关分布、只覆盖受限分布族或覆盖特定跨域关系，对学习算法提出的要求不同。

同样，风险与容量必须随比较空间解释。“误差小”可以指总风险小，也可以指相对于 $\mathcal{W}$ 中最低风险的差距小。若算法始终返回 $\mathcal{W}$ 中的决策，称为**恰当学习**（proper learning）；若允许返回 $\mathcal{W}$ 之外而在 $\mathcal{W}_{\mathrm{out}}$ 中的决策，称为**非恰当学习**（improper learning）。两种学习仍以 $\mathcal{W}$ 的最低风险比较，改变的是可交付结果及相应的算法接口。

保证中的概率也要明确对谁取平均。新观测决定固定决策的期望损失，训练样本与算法随机数决定训练成功的概率，环境抽样还可能增加一层随机性；相应的期望、高概率和逐环境保证约束不同对象。可测性与可分性使这些概率及经验过程上确界有定义。统计保证控制样本量，可计算性要求程序停机，高效性还限制训练与预测时间。分类、实值损失和跨域学习可以复用这些职责，但改变任何一项都须重新核对保证，并在具体定理中补齐有界性、凸性或覆盖条件。

**可测性与可分性约定**　算法看过样本再选决策，风险分析因此常须同时比较一组损失。对需要取上确界的 $\mathcal{W}' \subseteq \mathcal{W}^{+}$，先将其损失写成函数类：

$$\mathcal{F}_{\ell}(\mathcal{W}') = \{z \mapsto \ell(w, z) : w \in \mathcal{W}'\}.$$

直接给定函数类时仍记为 $\mathcal{F}$。本部分要求一致有界类中的函数均可测，且有可数子类 $\mathcal{F}_0$，使任意 $f \in \mathcal{F}$ 都是其中一个序列的逐点极限。若 $\mathcal{F} = \mathcal{F}_{\ell}(\mathcal{W}')$，为 $\mathcal{F}_0$ 的每个函数固定一个代表决策，得到可数 $\mathcal{W}_0 \subseteq \mathcal{W}'$ 及 $\mathcal{F}_0 = \mathcal{F}_{\ell}(\mathcal{W}_0)$。学习、压缩、重构及其他数据依赖输出映射还须可测。

这些条件使不可数比较可以回到可数对象上。逐点逼近先保证固定有限样本的经验平均收敛，一致有界再通过有界收敛保证期望平均收敛，相关上确界因此可在可数子类上计算。给定 $\rho > 0$，按 $\mathcal{W}_0$ 的固定枚举选第一个满足 $\hat{R}_S(w) \le \inf_{v \in \mathcal{W}_0} \hat{R}_S(v) + \rho$ 的决策，就得到可测选择：下确界和比较事件都可测，而逐点逼近给出 $\inf_{v \in \mathcal{W}_0} \hat{R}_S(v) = \inf_{v \in \mathcal{W}'} \hat{R}_S(v)$。这也是原集合上的近似 ERM。无法建立可数逼近或可测选择时，须改用外概率或另加经验过程条件；无界损失则另行检查可积性与矩条件。

### 4.1.2 二分类例子

现在取邮件作为观测，把统一设定落实到二分类。令 $Z = X \times Y$、$Y = \{0, 1\}$，以假设空间 $\mathcal{H}$ 同时作为比较空间与输出空间，并用 $\ell(h, (x, y)) = \ell_{01}(h(x), y)$ 记录预测是否出错。接下来的阈值例子将说明有限标签怎样限制候选假设，也为可实现与不可知两种比较基准提供共同对象。

算法用已知类别的邮件选择预测规则。标签即使完全正确，也只约束已经观察到的邮件，可能留下几条对训练数据回答相同、对新邮件回答不同的规则。

设每封邮件都已有一个 $[0, 1]$ 中的可疑程度分数。较高分数表示评分程序将这封邮件判断为更可疑，并不必然表示相应的垃圾邮件概率。我们固定评分程序，只学习分类的分界：分数达到分界时判为垃圾邮件，低于分界时判为正常邮件。这个分界值称为**阈值**（threshold），学习任务就是根据标签选择它。

用四封人为构造的邮件检验这一选择。分数 0.1 与 0.3 对应正常邮件，0.7 与 0.9 对应垃圾邮件。阈值 0.4 和 0.6 都把前两封判为正常、后两封判为垃圾，所以训练错误都为零。两个阈值之间没有训练邮件，已见标签便无法进一步判断阈值应落在哪里。

分数为 0.5 的新邮件正好落在两条规则的分歧处。由于 $0.5 \geq 0.4$，第一条规则预测垃圾邮件；由于 $0.5 < 0.6$，第二条规则预测正常邮件。表 4.1把已见与未见输入放在一起比较。新邮件尚无真实标签，我们不能判定哪条规则正确，但能据此确认：四封训练邮件未能排除这项分歧。

| 邮件分数 | 已知类别 | 阈值 0.4 的预测 | 阈值 0.6 的预测 |
|---|---|---|---|
| 0.1 | 正常 | 正常 | 正常 |
| 0.3 | 正常 | 正常 | 正常 |
| 0.7 | 垃圾 | 垃圾 | 垃圾 |
| 0.9 | 垃圾 | 垃圾 | 垃圾 |
| 0.5 | 尚未标注 | 垃圾 | 正常 |

表 4.1　四封构造的训练邮件与一封未标注邮件上的阈值预测。两个阈值分对全部训练记录，却在分数 0.5 处产生分歧；末行没有真实标签，故不能据它判断谁正确。

在这个例子中，邮件分数是分类器可读取的**输入**，记为 $x$；人工给出的真实类别是**标签**，记为 $y$。约定垃圾邮件为 1、正常邮件为 0，所有允许输入组成 $X = [0, 1]$，所有标签组成 $Y = \{0, 1\}$。实际输入也可以是多个特征组成的向量；输入与标签的职责不随这种表示变化。

阈值一旦选定，就得到一条对每个允许输入给出类别的规则，称为**假设**（hypothesis），写作函数 $h : X \to Y$。例如 $h(0.5) = 1$ 只陈述这条规则对分数 0.5 的预测；真实标签仍须另行观察，不能由预测值替代。

算法允许选择的全部假设组成非空的**假设空间**（hypothesis space），记为 $\mathcal{H}$。当前只调整阈值，故以全部允许 $t$ 为索引写出候选：

$$\mathcal{H}_{\text{thr}} = \{h_t : t \in [0,1]\}, \qquad h_t(x) = \begin{cases} 1, & x \geq t, \\ 0, & x < t. \end{cases} \tag{4.1}$$

下标 $t$ 标明采用哪条规则。$h_{0.4}$ 与 $h_{0.6}$ 是其中两个成员，训练选择 $t$ 之后，预测再使用对应的 $h_t$。

阈值空间把不同输入的预测联系起来：越过阈值后，分数继续上升不会使预测变回正常邮件。训练数据并没有迫使我们采用这条限制，逐条记住四个输入并任意回答其他输入，也可以分对训练邮件。预先限定候选假设或规定选择偏好，称为**归纳偏置**（inductive bias）。它补充了样本之外的规则，使算法能在未见输入上延伸已有判断。

奥卡姆剃刀表达优先采用简单解释的想法。在阈值例子里，描述一个分界值即可指定假设，记忆型规则则须保存每个训练输入。不过，描述长度取决于编码方式，不能仅凭“简单”二字推出泛化。还需要证明这种表示限制怎样控制统计误差。

**损失、期望风险与经验风险**　比较候选时，先把预测错了多少转成代价。**损失**（loss）为一次预测计分；当前对两种误判同等计分，错分记 1，正确记 0。这称为**零一损失**（zero-one loss）。以 $h(x)$ 为预测、$y$ 为真实标签，有

$$\ell(h,(x,y)) = \ell_{01}(h(x),y) = \begin{cases} 1, & h(x) \neq y, \\ 0, & h(x) = y. \end{cases} \tag{4.2}$$

若误删正常邮件的代价更大，这一对称计分就须更换。下文先固定零一损失，以免比较时改变评价口径。

一次预测的损失只评价一封邮件。若分类器分错 100 封已标注邮件中的 3 封，样本平均损失是 $3/100 = 0.03$；它直接可算，却只描述这 100 封邮件。我们要评价未来表现，还须计算随机到来的一封邮件被分错的概率，这需要知道不同邮件及其标签出现的频率。

以联合分布 $\mathcal{P}$ 表示这种来源。它同时记录输入分数出现的频率与相应标签的概率，作用于 $z = (x,y) \in Z = X \times Y$。例如，两条阈值规则只在很窄的区间上不同，若邮件恰好大量集中在那里，二者的未来错误率仍可相差很多。算法通常只看到来自 $\mathcal{P}$ 的样本，并不知道完整分布。

按 $\mathcal{P}$ 平均未来损失，就得到 $h$ 的期望风险。零一损失只取 0 或 1，其平均也就是分类错误的概率：

$$R_{\mathcal{P}}(h) = \mathbb{E}_{(x,y)\sim\mathcal{P}}[\ell_{01}(h(x),y)] = \mathbb{P}_{(x,y)\sim\mathcal{P}}(h(x) \neq y). \tag{4.3}$$

算法无法直接计算这个未知分布平均，但可计算样本平均。对 $S = (z_1, \dots, z_n)$、$z_i = (x_i, y_i)$，定义经验风险为

$$\hat{R}_S(h) = \frac{1}{n} \sum_{i=1}^{n} \ell_{01}(h(x_i), y_i). \tag{4.4}$$

分子累计样本错误数，除以 $n$ 后给出这份样本中的错误比例。

下标区分了两种平均：$R_{\mathcal{P}}$ 依赖总体分布，$\hat{R}_S$ 依赖已经观察到的样本。所谓“经验”就是依据样本计算。$S$ 取训练集时，它给出训练平均损失；换成独立测试集时，它给出另一次对未来损失的样本估计。两者都不会因为能够直接计算而等于未知的总体风险。

我们还可以在同一个假设上比较总体平均与样本平均。两者的差 $R_{\mathcal{P}}(h) - \hat{R}_S(h)$ 称为**泛化差**（generalization gap），可能为正，也可能为负。它考察评价样本造成的偏离。后面的超额期望风险则比较学习结果与基准的两个总体风险，考察学习结果距基准有多远。

四封训练邮件只让我们知道两条阈值的经验风险都为零，尚不足以计算总体风险。为做一次可复算的教学比较，另设分数在 $[0, 1]$ 上均匀分布，且真实垃圾邮件恰为分数不低于 0.6 的邮件。于是 $h_{0.6}$ 处处正确，$h_{0.4}$ 只在 $[0.4, 0.6)$ 误把正常邮件判为垃圾。该区间概率为 0.2，两条规则的期望风险便分别为 0 和 0.2。结果来自补充的分布与标签规律，不能归为四封训练邮件本身提供的证据。

**样本与学习算法**　用样本比例推断未来风险，还须连接两批数据的来源。**独立同分布**（independent and identically distributed, i.i.d.）要求训练观测彼此独立，且各自服从评价所用的同一个 $\mathcal{P}$。$n$ 个观测的联合分布因此是

$$S = \big((x_1, y_1), \dots, (x_n, y_n)\big) \sim \mathcal{P}^n. \tag{4.5}$$

这个理想化条件需要针对数据检查。重复转发可能造成依赖，部署后的邮件类型变化可能使评价不同于训练。后一情形须加入第 9章分析的跨域条件。

从样本到假设的选择过程称为**学习算法**（learning algorithm），记为 $A$；一次训练输出 $\hat{h} = A(S)$。例如，算法可以比较各阈值的训练错误数并选取最小者。若多个阈值并列，还须有确定的选解约定。$A$ 规定怎样选择，$\hat{h}$ 是这份样本下选出的结果。

本章先令 $\mathcal{W}_{\text{out}} = \mathcal{H}$，采用第 4.1节定义的恰当学习。若候选只有单阈值规则，算法却组合规则得到不再属于该空间的分类器，就须将它纳入更大的输出空间；后文使用非恰当输出时会明示这种变化。

样本变化会使同一算法选出不同假设。一批邮件可能包含许多接近真实分界的输入，另一批恰好缺少它们，训练阈值便可能不同。因此，固定一个训练结果估计其风险，与重复抽样考察算法有多大机会得到低风险结果，是两层评价。

图 4.1将两层随机性分开画出。固定 $\hat{h}$ 后，$R_{\mathcal{P}}(\hat{h})$ 只对新邮件平均；重新抽取 $S$ 时，$A(S)$ 改变，它的总体风险也随之改变。学习保证控制的是后一次变化产生高风险结果的概率。算法若使用内部随机数，也须把这些随机选择纳入成功概率。

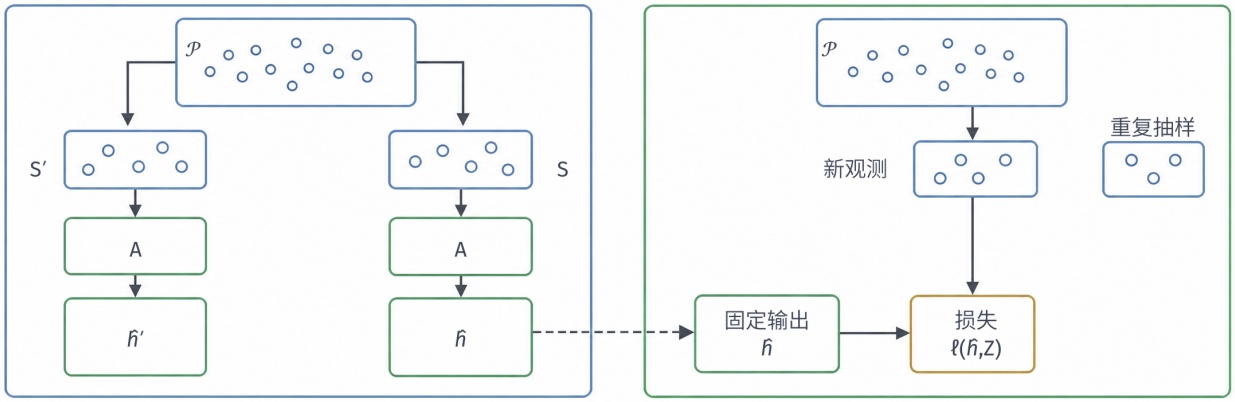


图 4.1　两层随机性的评价对象。固定训练输出后，右侧新观测的平均损失给出期望风险；左侧重新抽样则改变输出，学习保证控制这种变化造成高风险结果的概率。

### 4.1.3 一般学习的风险与可学习性

式 (4.3)与(4.4)已经给出了分类中的两种平均。对回归函数、聚类中心等决策，可沿用相同计算关系：以一般观测 $z$ 替代输入标签对，以决策 $w$ 替代分类器 $h$，损失仍由任务指定。这样推广的是风险的定义形式，零一损失下“错误概率”的解释则不随之推广。

**定义 4.2　一般学习问题的期望风险**　设 $\mathcal{P} \in \mathfrak{P}$。对任意 $w \in \mathcal{W}^{+}$，若 $\ell(w,\cdot)$ 在 $\mathcal{P}$ 下可积，则 $w$ 的期望风险为

$$R_{\mathcal{P}}(w) = \mathbb{E}_{z\sim\mathcal{P}}\ell(w,z).$$

**定义 4.3　一般学习问题的经验风险**　给定样本 $S = (z_1,\dots,z_n) \in Z^n$，任意 $w \in \mathcal{W} \cup \mathcal{W}_{\text{out}}$ 的经验风险为

$$\hat{R}_S(w) = \frac{1}{n}\sum_{i=1}^{n}\ell(w,z_i). \tag{4.6}$$

在训练与评价同分布的基线下，我们以 $\mathcal{W}$ 中的最低期望风险作比较。即使这个基准非零，也可要求输出只比它高出一个预先指定的容差，并让训练失败概率对允许的分布统一受控。

PAC 学习（probably approximately correct learning）将这一要求写成两个容限。$\varepsilon$ 约束输出风险比比较空间最低风险高出多少，$\delta$ 约束随机样本与算法随机性导致超出该容限的概率。可学习性要求同一个算法对任意预先选定的 $\varepsilon, \delta \in (0,1)$，在足够大的样本量下满足两项要求。

这些比较首先要有定义。下文默认 $\inf_{w \in \mathcal{W}} R_{\mathcal{P}}(w)$ 有限，随机输出的风险几乎处处有限，并且 $R_{\mathcal{P}}(A(S,U))$ 对 $(S,U)$ 可测。无界损失的具体定理还须用可积性或矩条件保证这些性质。满足统计量的定义条件之后，PAC 讨论能否学到；程序实现另加计算要求。

**定义 4.4　相对于分布族的 PAC 可学习性**　若存在算法 $A$，对任意 $\varepsilon, \delta \in (0,1)$ 存在整数 $n_0(\varepsilon,\delta)$，使任意 $\mathcal{P} \in \mathfrak{P}$ 和 $n \geq n_0(\varepsilon,\delta)$ 均满足

$$\mathbb{P}_{S \sim \mathcal{P}^n, U}\left\{ R_{\mathcal{P}}(A(S,U)) \leq \inf_{w \in \mathcal{W}} R_{\mathcal{P}}(w) + \varepsilon \right\} \geq 1 - \delta,$$

则称该学习问题相对于 $\mathfrak{P}$ 是 PAC 可学习的。概率包含训练样本和算法内部随机数；确定性算法省略 $U$。只有当 $\mathfrak{P}$ 包含所讨论空间上的全部相关分布时，才称这一保证为分布无关。

定义 4.4尚未约束程序的执行。若训练在给定编码下停机，且输出的预测程序对每个允许输入停机，得到**可计算学习**（computable learning）；再要求样本量、训练时间与预测时间有约定参数的多项式上界，得到**高效学习**（efficient learning）。第 4.2.3节会在二分类中落实这两种附加要求。

## 4.2　PAC 学习

例如，在可实现二分类中，要求“以至少 99% 的概率得到未来错误率不超过 5% 的分类器”，就是取 $\delta = 0.01$、$\varepsilon = 0.05$。5% 约束固定训练结果在分布上的错误概率，99% 约束随机抽样并训练的成功机会。它既不要求分对每个训练样本，也不要求每批未来邮件都出现至多 5% 的实际错误。

有限样本会遗漏输入，所以通常只能允许小概率失败，再用更多样本使失败概率低于指定的 $\delta$。成功时的风险应接近零还是接近类内最低值，则由是否存在完美分类器决定。两种情况共享定义 4.4的概率量词；取比较空间 $\mathcal{H}$ 与零一损失后，可实现与不可知设定分别规定允许的分布及风险基准。

### 4.2.1 可实现情形

先假设 $\mathcal{H}$ 中确有一个在总体上零错误的假设。这个可实现条件暂时排除了标签噪声及表示限制带来的不可避免风险，让我们集中分析：未知目标已经在空间内，有限观测是否足以选出低风险假设。

**定义 4.5　可实现性**　如果某个假设能够以概率 1 正确预测数据来源中的标签，就称数据分布对该假设空间是**可实现的**（realizable）。形式上，分布 $\mathcal{P}$ 对 $\mathcal{H}$ 可实现，是指存在 $h^\star \in \mathcal{H}$ 满足

$$R_{\mathcal{P}}(h^\star) = 0.$$

前面的教学分布由阈值 0.6 确定真实标签，而 $h_{0.6}$ 属于阈值空间，故该分布可实现。若同一分数可以伴随两种标签，分数本身就未必足以作出零错误预测。这里要求的是总体中的零风险假设存在；一张训练表碰巧没有冲突，只检验了有限观测，不能据此确认可实现性。

存在零风险假设，并没有告诉算法应选哪个。我们要求预先确定的同一算法处理所有可实现分布，充分样本量只依赖 $\varepsilon$、$\delta$ 与 $\mathcal{H}$。若样本量还随未知的具体分布临时确定，就没有得到这种统一保证。

将定义 4.4的允许族限定为对 $\mathcal{H}$ 可实现的全部分布，记样本量阈值为 $m_{\mathcal{H}}$。此时类内最低风险为零，成功事件化为

$$\mathbb{P}_{S\sim\mathcal{P}^n}\left(R_{\mathcal{P}}(A(S)) \le \varepsilon\right) \ge 1-\delta. \tag{4.7}$$

若同一个算法对所有这些分布达到该要求，就称 $\mathcal{H}$ 可实现 PAC 可学习。$m_{\mathcal{H}}(\varepsilon,\delta)$ 可以依赖两项容限及假设空间，不能随具体未知分布改变。

在所有算法中，使该保证从某个样本量起对全部更大样本量成立的最小阈值，称为**样本复杂度**（sample complexity）。找到一个满足条件的 $m_{\mathcal{H}}(\varepsilon,\delta)$，只证明了它是充分上界，尚未证明它最小。算法随机化时，成功概率也包含内部随机数。

式 (4.7)的内层先评价一次训练：$A(S)$ 是所得分类器，$R_{\mathcal{P}}(A(S)) \le \varepsilon$ 就是成功事件，在零一损失下表示总体错误概率不超过 $\varepsilon$。外层再对训练样本的随机抽取计数，要求这个事件发生的概率至少为 $1-\delta$。

算法与样本量须在未知分布之前确定。若知道分布后才为它挑算法或另定样本量，所得结论只覆盖各自特定来源。分布无关学习要求同一个算法与同一个样本上界覆盖全部允许分布。PAC 的计算形式化由 Valiant 提出；本章采用统计学习教材中的分布无关表述[1]。

[1] L. G. Valiant, *A Theory of the Learnable* In Communications of the ACM, 1984, vol. 27, no. 11, pp. 1134–1142

两个容限也约束不同的改进：减小 $\varepsilon$ 使成功结果的风险更低，减小 $\delta$ 使训练失败更少。它们需要增加多少样本，须从假设空间与算法推导。第 5章将用有限空间给出这种计算。

上面的保证能指定任意小精度，称为**强学习**（strong learning）。若只要求成功时比等概率随机猜测好一个固定幅度，则得到**弱学习**（weak learning）。在可实现二分类中，要求存在 $\gamma \in (0, 1/2)$、同一算法 $A$ 和有限 $m_{\mathcal{H}}^{\mathrm{weak}}(\delta)$，对任意 $\delta \in (0,1)$、全部可实现 $\mathcal{P}$ 及 $n \geq m_{\mathcal{H}}^{\mathrm{weak}}(\delta)$ 满足

$$\mathbb{P}_{S\sim\mathcal{P}^n,U}\left(R_{\mathcal{P}}(A(S,U)) \leq \frac{1}{2} - \gamma\right) \geq 1 - \delta,$$

这时称 $\mathcal{H}$ 弱 PAC 可学习。$\gamma$ 不随分布、样本或 $\delta$ 变化，$U$ 独立于样本并表示内部随机性，确定性算法省略它。取 $\gamma = 0.1$ 时，成功结果至多 40% 错误，比不看输入的公平猜测低 10 个百分点。第 5.6节还将区分目标与输出空间：重加权改变各轮分布，同一学习器与优势必须适用于仍由目标空间实现的每轮分布，并分配总失败预算。一次略优于猜测的训练结果尚未满足这一接口。

### 4.2.2 不可知情形

如果假设空间没有零风险成员，可实现保证就失去了前提。在应用中，这一前提常无法确认，有时已知不成立。此时应先判断输入和假设空间允许达到什么风险，再评价算法是否达标，不能把未达到零风险直接算作训练失败。

零风险不可达可能来自输入信息不足，也可能来自假设空间遗漏了决策规律。前者即使知道完整分布仍留下错误，后者使类内最低风险高于所有可测分类器的最低风险。第 4.4节会用贝叶斯风险与近似误差分别刻画二者。噪声的解释也取决于评价标签：若观测标签本身作为 $y$，噪声属于 $\mathcal{P}$；若训练与评价用不同标签，须另加二者关系，原同分布保证不能直接使用。

因此，我们改用类内最低风险作为成功基准，同时不对噪声模型预作限制。**不可知设定**（agnostic setting）要求结果接近这个基准，而不承诺零风险目标已经在 $\mathcal{H}$ 内。“不可知”撤去的是这项先验承诺，训练标签与独立同分布抽样仍然保留。

假设 $\mathcal{H}$ 的最低期望风险是 8%。要求恰当学习器达到 2% 总风险就不可能满足；要求它比类内最低风险至多多 2 个百分点，则允许总风险达到 10%。学习输出的期望风险与类内最低风险之差称为**超额期望风险**（excess risk）。它的参照始终是同一个 $\mathcal{H}$，本例的容限为 2 个百分点。

我们要比较的是可逼近的最低风险，未必存在恰好最优的成员。因此以 $R^{\star}_{\mathcal{P},\mathcal{H}}$ 记下确界：

$$R^{\star}_{\mathcal{P},\mathcal{H}} = \inf_{h\in\mathcal{H}} R_{\mathcal{P}}(h). \tag{4.8}$$

例如候选风险依次为 $0.08 + 0.1/k$，可趋近 0.08 却不必取到 0.08。下确界保留这个最佳逼近水平，无需额外假定最优假设存在。

再将定义 4.4中的允许族取为 $X \times Y$ 的全部相关联合分布，记充分样本阈值为 $m^{\mathrm{agn}}_{\mathcal{H}}$。相对于上述下确界，要求

$$\mathbb{P}_{S\sim\mathcal{P}^n}\left(R_{\mathcal{P}}(A(S)) \le R^{\star}_{\mathcal{P},\mathcal{H}} + \varepsilon\right) \ge 1-\delta. \tag{4.9}$$

满足该统一保证时，就说 $\mathcal{H}$ 是**不可知 PAC 可学习的**（agnostic PAC learnable）。容限 $\varepsilon$ 限制的是超额期望风险，而非全部分类风险。

可实现分布也在不可知保证覆盖的范围内。其类内最低风险为零，式 (4.9)便成为可实现保证。因此不可知学习扩大了需要统一处理的分布，而非任意放宽成功标准。类内最低风险只用于评价结果，算法无须事先知道它；这与可实现学习无需知道零风险假设是谁相同。

### 4.2.3 计算要求

前面的 PAC 定义把算法写作从样本到分类器的映射，回答有限信息是否允许可靠预测。一个满足保证的映射存在，还不足以说明计算机怎样实现它。

实现需要训练和预测都能完成，也需要核算计算量随规模怎样增长。可计算 PAC 与高效 PAC 分别加上停机要求和资源上界，统计风险保证仍须成立。

核算之前先固定编码。自然数输入可写为二进制字符串，二分类标签占一个比特，假设可由计算预测的程序表示，学习器输出该程序的有限描述。任意实数却未必有有限精确编码；连续输入上的任意精度运算需要约定精度或计算模型，不能默认按一次常数时间操作计费。

> **定义 4.6　可计算 PAC 学习**　在固定的有效表示下，如果存在一个可执行的学习程序，能够在每个允许的有限训练样本上停机，输出一个对每个允许输入都能停机并给出标签的预测程序，并且该学习算法满足 PAC 保证，就称该假设空间是可计算 PAC 可学习的（computably PAC learnable），简称 CPAC 可学习。这里的 PAC 保证可以采用可实现版本或不可知版本，使用时必须说明采用哪一种。

停机要求同时覆盖训练与使用。指定“返回期望风险最小者”没有提供寻找它的程序，输出一段可能永不返回的代码也没有提供总可用的预测规

则。允许很慢但最终完成，已经满足可计算性；多项式时间是另一项要求。输出须在 $\mathcal{H}$ 中时得到恰当 CPAC，允许空间外分类器时得到非恰当 CPAC。本章默认恰当输出，引用文献结论时须保持输出约定一致。

训练可执行也不等于能算出充分样本上界。前者保证给定有限样本后能完成训练，后者要求根据 $\varepsilon, \delta$ 返回足够大的样本数。基本 CPAC 未自动要求后者，附加可计算样本上界的版本及分离结果见 Delle Rose 等[2]。第 5.7节将以可计算缺失标记说明这项区别。

[2] V. Delle Rose, A. Kozachinskiy, C. Rojas, T. Steifer, *Find a Witness or Shatter: The Landscape of Computable PAC Learning* In Proceedings of the 36th Conference on Learning Theory, 2023, pp. 511–524

有限穷举可实现，却可能需要指数时间。设假设由 $d$ 比特索引，有 $2^d$ 个成员且各可多项式时间求值。逐一算经验风险仍要检查指数多个候选。定理 5.1给出的可实现充分样本量只按下式增长：

$$\frac{d \log 2 + \log(1/\delta)}{\varepsilon}$$

样本的线性规模与穷举的指数规模并不冲突，它们分别衡量信息与搜索成本。这个比较只排除了穷举的高效性，未排除利用结构的更快算法。

**定义 4.7　高效 PAC 学习**　高效 PAC 学习（efficient PAC learning）要求在满足 PAC 期望风险保证的同时，样本量、训练计算量及输出分类器的预测计算量都有多项式上界。为明确规模依赖，考虑由参数 $d$ 描述的一族假设空间 $\mathcal{H}_d$，并约定观测编码长度上界为 $b$。本书采用的高效性约定要求存在统一程序和固定多项式 $p, q$，使所需样本量及训练时间分别满足

$$\begin{aligned} m_{\mathcal{H}_d}(\varepsilon, \delta) &\le p\big(d, b, 1/\varepsilon, \log(1/\delta)\big), \\ T_{\text{train}} &\le q\big(n, d, b, 1/\varepsilon, \log(1/\delta)\big). \end{aligned} \tag{4.10}$$

学习程序把 $d, \varepsilon, \delta$ 及样本编码作为输入；若 $\varepsilon, \delta$ 只通过预先给定的样本量体现，也必须明确这一接口。输出分类器属于预先规定、可统一求值的表示族，它在新输入上的求值时间应被 $d$、输出表示长度和输入编码长度的某个固定多项式所控制，不能仅把任意程序的短代码长度当作预测高效的依据。若这族假设空间还由目标描述长度等量参数化，也须将它们明确列入规模变量。

规模参数 $d$ 由问题约定，不一定是特征维数；编码长度 $b$ 使长数值的读写与比较计入成本。统一多项式还要求次数不随 $d$ 增长。不同文献有时使用 $1/\delta$，有时使用 $\log(1/\delta)$ 描述资源，引用时须核对。即使满足多项式上界，大常数或高次数也可能使实际计算难以承受。

阈值的顺序结构提供了比穷举更少的搜索位置。设输入为 $1, \dots, M$ 中的整数，$h_t(x) = \mathbb{I}\{x \ge t\}$，$t \in \{1, \dots, M+1\}$。样本上的预测只在阈值越过一个已见输入时改变。将样本排序并合并重复输入后，我们可扫描切分位置，

累计左侧正标签数与右侧负标签数，选择错误最少者。排序与扫描分别需要 $O(n \log n)$ 次比较和 $O(n)$ 次累计，每次整数运算另按 $\log M$ 计位成本。预测只需一次阈值比较。结合有限空间的样本界，这个算法在所述编码下满足高效 PAC 要求。

固定风险目标、表示与输出范围后，高效 PAC 蕴含可计算 PAC，可计算 PAC 蕴含统计 PAC；逆向均须补充条件。可实现与不可知限制数据分布，恰当与非恰当限制输出，可计算与高效限制执行方式。这些要求可以组合使用，不能以其中一项替代另一项。

## 4.3 学习的限制

对未知 $\mathcal{P}$，算法不能直接比较期望风险，却能逐条计算训练损失。选择经验风险最小者便成为一个可用的训练原则。前面的阈值 0.4 与 0.6 在四封邮件上都零错误，也都可能按这个原则被选中。

**定义 4.8　经验风险最小化**　经验风险最小化（empirical risk minimization, ERM）是在给定假设空间中，选择训练样本平均损失最小的假设作为学习结果。用 $A_{\mathrm{ERM}}$ 表示这种学习算法，则

$$A_{\mathrm{ERM}}(S) \in \arg\min_{h \in \mathcal{H}} \hat{R}_S(h). \tag{4.11}$$

这里 $\arg\min$ 表示所有达到最小经验风险的假设组成的集合。若最小值不能取得，可以要求输出的经验风险与下确界相差不超过一个给定容差。

$\arg\min$ 是一组经验最优解，公式中的“$\in$”允许算法选其中任意一个。ERM 本身尚未指定并列解怎样选择。两条阈值的经验风险相同而未见预测不同，说明要从经验最优推到 PAC 成功，必须另行控制未观察区域的风险。

扩大样本也未必消除这种差别。若空间允许按每份样本特制记忆规则，新增数据可以只使记忆表变长。下面用连续输入上的有限记忆规则，检验零训练错误能否单独推出低期望风险。

### 4.3.1 记忆训练样本

仍以 $[0,1]$ 中的邮件分数作输入，这次令它均匀分布，区间概率等于长度，并令所有真实标签都为垃圾邮件。这是人为简化的分布，便于直接比较记忆与推广。

始终预测垃圾邮件的规则在此分布上零错误。另一个规则只保存训练分数：查到记忆表中的分数时预测垃圾邮件，表外分数则预测正常邮件。二者都能分对训练邮件，但表外预测相反。

将记忆表写成有限分数集合 $C$，规则为

$$h_C(x) = \begin{cases} 1, & x \in C, \\ 0, & x \notin C, \end{cases} \tag{4.12}$$

再令 $h_{\text{all}}(x) = 1$，把它与全部有限表规则 $h_C$ 一起放入假设空间。每条规则可测，且 $h_{\text{all}}$ 的总体风险为零，故这个分布可实现。

以 $C_S$ 记录样本 $S$ 出现过的全部不同输入。选择 $h_{C_S}$ 是一个合法的零经验风险选解，但它的两项风险为

$$\hat{R}_S(h_{C_S}) = 0, \qquad R_{\mathcal{P}}(h_{C_S}) = 1. \tag{4.13}$$

每个训练点都在表内，所以第一项为零；连续均匀分布落在任意有限集合的概率为零，所以新输入几乎必在表外，第二项为 1。零训练错误与几乎处处预测错误在同一规则上同时成立。

始终选 $h_{\text{all}}$ 的 ERM 在这个例子中仍能成功，反例只证明 ERM 原则不能单独约束选解。它要求已见点上的损失最小，却允许在表外任意回答。第 5.2节将用一致收敛连接经验风险与总体风险，使所有经验最优解都接近类内最低期望风险。

### 4.3.2 没有免费的午餐

记忆规则失败后，一个自然的问题是：换一套选择规则，能否对任意标签规律都保证成功？如果假设空间允许许多输入的标签彼此无约束地变化，未见标签就没有可由已见标签推断的联系。**没有免费的午餐**（no-free-lunch）定理把这一信息缺口写成适用于任意有限样本算法的失败下界。

设算法只看到 $n$ 个观测，而空间能实现某 $2n$ 个输入上的全部二元标签组合。我们将固定输入出现的概率，再为算法选择一套标签规律。这套规律在 $\mathcal{H}$ 中有零风险实现，算法却以至少 $1/7$ 的概率得到期望风险不低于 $1/8$ 的结果。下面的构造解释两个数值从哪里来。

算法不知道完整输入分布及标签表，只观察抽到的 $n$ 个记录。$2n$ 个输入无法全部出现，未见点的标签又可以独立改变，所以拟合已见数据不能排除在未见点大量出错的可能。这里用总体风险超过容限判定失败，训练错误仍可为零。

先用四个输入观察歧义。令 $X = \{1, 2, 3, 4\}$ 且四者等概率出现，编号仅用来区分对象，不提供类别或相似性信息。假设空间允许全部二分类函数。若训练只出现 $(1, 0)$ 与 $(2, 1)$，编号 3 与 4 的标签仍然未见。

完整标签表 $(0, 1, 0, 0)$ 与 $(0, 1, 1, 1)$ 分别记为 $f_0, f_1$。它们在训练点上完全相同，都解释已见标签，在编号 3、4 上却处处相反。因此“与样本一致”只表示在观察到的点上回答正确。图 4.2并列画出这两套隐藏真值。

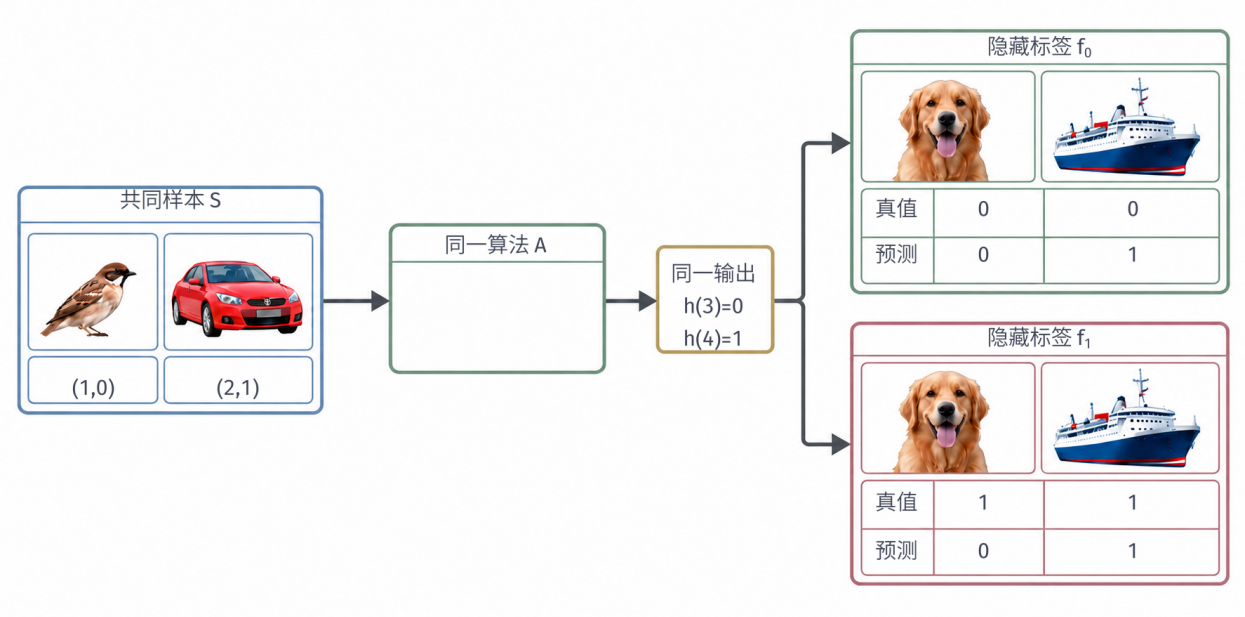


图 4.2 相同样本与两套隐藏标签。鸟、汽车、狗、船分别表示编号 1 至 4，每个概率为 1/4；两套来源在已见编号 1、2 上同为 0、1，未见编号 3、4 则分别全为 0 或全为 1。图示输出 $h(3) = 0, h(4) = 1$ 在每套来源各错一个点。固定样本与内部随机数后输出相同，任意二元预测在每个未见点的两份损失相加为 1，故风险之和至少 1/2。这里展示固定样本的歧义，下文再证明随机抽样下的固定困难分布。

预测编号 3 时，$f_0$ 要求回答 0，$f_1$ 要求回答 1。两套真值交给算法的样本都是 $(1, 0), (2, 1)$，算法无法用这份样本辨认当前是哪一套。它可以按偏好选择一个标签，但该偏好仍可能与真实标签相反。

把所有假设枚举出来仍只能发现 $f_0, f_1$ 都零训练错误。枚举提供了候选规则，没有提供二者在编号 3 上谁正确的证据。要消除歧义，须观察该标签，或加入已见与未见标签之间的联系。

同样的歧义可放在 $2n$ 个等概率输入上。给定 $n$ 个观测，未见集合 $U$ 至少含 $n$ 点。两张表在已见处相同、在 $U$ 上相反时，同一输出 $h$ 在每个未见点的两份零一损失相加为 1，故

$$R_{\mathcal{P}_0}(h) + R_{\mathcal{P}_1}(h) \geq \frac{|U|}{2n} \geq \frac{1}{2}.$$

至少一张表使这次输出的风险不低于 1/4。此处仍在固定样本下对照候选；下文须把候选平均，才能在抽样之前选定一个困难分布。

固定样本下的两套标签表展示了信息歧义，但学习定理要求固定分布在随机抽样时仍然困难。为满足这个量词顺序，我们将对全部标签配置平均，再从中选定一个分布[3]。

[3] S. Shalev-Shwartz, S. Ben-David, *Understanding Machine Learning: From Theory to Algorithms*, Cambridge University Press, 2014, 1st ed.

**定理 4.9　没有免费的午餐**　设 $n \geq 1$，固定输入空间 $X$ 中有一个含 $2n$ 个不同点的集合 $C$。假设无论怎样为 $C$ 中的每个点分别指定标签 0 或 1，都能从 $\mathcal{H}$ 中找到一个分类器，使它在 $C$ 上的预测与这些指定标签完全一致；不同的标签组合可以由 $\mathcal{H}$ 中的不同分类器实现。则对任意使用 $n$ 个独立同分布训练观测的二分类学习算法 $A$，都存在一个对 $\mathcal{H}$ 可实现的分布 $\mathcal{P}$ 及 $f^\star \in \mathcal{H}$，使 $R_{\mathcal{P}}(f^\star) = 0$，但

$$\mathbb{P}\left(R_{\mathcal{P}}(A(S)) \geq \frac{1}{8}\right) \geq \frac{1}{7}. \tag{4.14}$$

这里概率对 $S \sim \mathcal{P}^n$ 及算法内部随机性计算。算法即使允许输出 $\mathcal{H}$ 以外的分类器，结论也成立。

**证明**　固定输入集合 $C$ 并让输入均匀出现，候选分布之间只改变标签表。对任意 $g : C \to \{0,1\}$，前提给出 $f_g \in \mathcal{H}$ 与它在 $C$ 上一致。按先抽输入、再取标签 $g(x)$ 的方式定义 $\mathcal{P}_g$，这个分布就由 $f_g$ 实现，风险为零。

暂时给 $C$ 中每个输入独立分配一个公平的二元标签，用来对候选标签表平均。每个点只分配一次，重复抽到它时标签保持不变。因此任意固定标签表仍对应无噪声的可实现分布；随机标签表是证明工具，不是训练过程中不断变化的真值。

固定训练输入、已见标签与算法随机数后，算法输出也已确定。$n$ 个观测至多涉及 $n$ 个不同输入，故 $C$ 中至少 $n$ 个输入未见。每个未见标签仍是独立公平的二元选择，无论输出在该点回答 0 还是 1，条件错误概率都是 $1/2$。

每个未见输入占概率 $1/(2n)$。风险非负，只累加至少 $n$ 个未见点已给出随机标签表下的下界：

$$n \times \frac{1}{2n} \times \frac{1}{2} = \frac{1}{4}. \tag{4.15}$$

三个因子依次为未见点数下界、单点概率与条件错误概率。再平均训练输入、已见标签和内部随机数仍有 $\mathbb{E}_g \mathbb{E}_{S,U} R_{\mathcal{P}_g}(A(S,U)) \geq 1/4$，其中 $U$ 表示内部随机数。

候选表只有有限张，平均至少为 $1/4$ 就必有固定 $g^\star$ 满足

$$\mathbb{E}_{S,U} R_{\mathcal{P}_{g^\star}}(A(S,U)) \geq \frac{1}{4}.$$

若每张表的平均风险都小于 $1/4$，总平均也会小于它，产生矛盾。现在固定 $\mathcal{P} = \mathcal{P}_{g^\star}$ 及 $f^\star = f_{g^\star}$，后续概率只包含从这个固定来源抽样与算法随机性。

最后把平均风险下界转成失败概率。令 $Z = R_{\mathcal{P}}(A(S,U)) \in [0,1]$、$p = \mathbb{P}(Z \geq 1/8)$。失败事件外 $Z < 1/8$，事件内 $Z \leq 1$，从而

$$\frac{1}{4} \leq \mathbb{E}Z \leq (1-p)\frac{1}{8} + p = \frac{1}{8} + \frac{7}{8}p.$$

移项即得 $p \geq 1/7$。 ■

困难分布是在算法 $A$ 与样本量 $n$ 固定后选出的。此后一切重复训练都从这个同一分布抽样，输入频率与标签表不再改变；以至少 $1/7$ 的概率，输出风险不低于 $1/8$。证明并未在看到某次样本后再改标签，因而给出的是固定来源上的随机训练失败，而非一份事后挑出的不利样本。

分布可以随 $A, n$ 变化，因为定理对每个算法及每个给定样本量分别构造反例。它没有要求同一个分布击败所有算法，也没有声称某算法在每个分布上都失败。算法仍可能处理许多有结构的来源；被排除的是在这些标签完全自由的允许分布上统一成功。

将这一有限样本结论用于固定的无限空间 $X = \mathbb{N}$，令 $\mathcal{H}$ 包含全部二分类函数。假设它 PAC 可学习，取 $\varepsilon = 1/16$、$\delta = 1/8$，便应有有限的统一充分样本量 $n \geq 1$。从同一个 $X$ 选出 $2n$ 个点，定理给出的可实现分布使风险至少为 $1/8$ 的概率不低于 $1/7$，同时超过所选误差与失败容限，形成矛盾。不能统一学习的是这一不受限制的空间，不是每个具体分布。

可实现性保证完整真值表 $f^\star$ 在 $\mathcal{H}$ 内，却未把这张表交给学习器。学习器只见 $n$ 个带标签记录。某编号若未出现，将其标签改成另一类而保持全部已见标签，就能得到同样解释样本的另一张表。零风险解存在与样本足以辨认其未见预测，是两项不同条件。

这也说明失败并非搜索时间不足。即使允许无限计算，算法依然看到同一份样本及彼此冲突的候选真值，无法靠搜索判断哪张表才是真实来源。第 4.2.3节的不可计算或时间过长限制执行；这里的限制来自缺少标签信息。

PAC 无需复原整张真值表，只要求总体风险低于 $\varepsilon$。上面的下界却已表明：任意有限统一样本量，都存在允许分布使该风险要求以过大的概率失

败。因而即使采用这个较弱的预测目标，也不能为不受限制的空间找到统一的有限样本阈值。

正面保证需要让一个标签约束其他输入的预测。例如，若阈值规则分对标签为 1、分数为 0.5 的邮件，必有 $t \le 0.5$，所有更高分数也就被预测为 1。观察一个标签排除了许多阈值，并限制了未见预测。若每个编号的标签都可自由选择，编号 1 的标签便不能提供编号 2 的任何信息。

限制假设空间或分布，正是在加入这种可以推广的联系。限制也有代价：若真实规律不满足它，所需假设会被排除。下一节在同一个风险口径下分析这项表达代价与有限样本的选择代价。

## 4.4 风险来源与模型选择

若垃圾邮件的分数落在两个分离区间，中间却是正常邮件，单阈值便不能同时圈出两段正类而排除中段负类。阈值限制能减少自由预测，却也留下训练数据无法消除的表达误差。要选择空间，须将这种误差与输入信息本身的不足分开。

输入信息不足可以在一个分数处看清。设分数 0.5 的邮件中 70% 为垃圾、30% 为正常，分类器只看到 $x = 0.5$，所以只能给出同一个预测。预测垃圾会错 30%，预测正常会错 70%，任意分类函数也无法低于 30% 的条件错误率。只要表示仍为该分数，更多样本或另一算法就不能区分这些邮件。

空间限制则是另一种情形。设三个输入分数为 0.2、0.5、0.8，标签分别确定为 1、0、1。输入足以区分它们，也存在全部分对的函数，但单阈值无法产生 1、0、1 的变化，每条阈值至少错一类。此时缺少的不是区分输入的信息，而是 $\mathcal{H}$ 中能利用这种信息的规则。

因此，先求当前输入下所有分类器的最低风险，再看选定空间使这个最低值增加多少。第一个基准由贝叶斯风险给出，第二个差距度量空间的表达限制。

**贝叶斯风险**（Bayes risk）是在当前输入信息下，全部可测分类器的最低错误概率。在条件风险有限、最小值达到且选择可测时，按给定结果分布选择条件期望损失最小的行动，就得到 Bayes 决策；这里采用二分类零一损失（可参考第一卷“策略的价值与优化”章的“单步价值下的行动选择”一节）。令 $\mathcal{H}_{\text{all}}$ 为全部可测二分类器，便有共同基准

$$R_{\mathcal{P}}^{\star} = \inf_{h \in \mathcal{H}_{\text{all}}} R_{\mathcal{P}}(h). \tag{4.16}$$

这个基准不限制分类器属于所选 $\mathcal{H}$，表示知道数据规律时可达到的水平，没有假定学习器已经知道它。

求共同基准可以先在一个输入 $x$ 处比较两种标签。设 $X$ 为标准 Borel 空间；更一般地，要求 $\mathbb{E}[\mathbb{I}\{y=1\} \mid x]$ 有可测版本。该版本按 $\mathcal{P}_X$ 几乎处处确定，选一个并记为

$$\eta(x) = \mathbb{P}(y = 1 \mid x),$$

它记录输入 $x$ 处标签为 1 的条件概率，标签为 0 的概率相应为 $1-\eta(x)$。

在 $x$ 处预测 1 的错误概率为 $1-\eta(x)$，预测 0 的错误概率为 $\eta(x)$。选择较小错误率，就应在 $\eta(x) \geq 1/2$ 时预测 1，否则预测 0；相等时两者均最优。逐点这样选择得到**贝叶斯分类器**（Bayes classifier），用所选可测版本写为

$$h^\star(x) = \mathbb{I}\{\eta(x) \geq 1/2\}.$$

每个输入处的最小条件错误率因而为

$$\min\{\eta(x), 1-\eta(x)\}.$$

在分数 0.5 处，$\eta(0.5) = 0.7$ 意味着两种预测的条件错误率分别为 0.3 与 0.7。贝叶斯分类器选择垃圾邮件，仍错其余 30% 的正常邮件。这个例子将“选多数标签”的规则与只观察分数时的不可避免错误联系起来。

条件错误率要按输入频率加权才能得到总体风险。例如分数 0.5 占全部邮件的 $q$，0.3 的条件错误贡献 $0.3q$。由联合分布忽略标签得到输入**边缘分布**（marginal distribution）$\mathcal{P}_X$，用它平均上述逐点最小值，得到

$$R^\star_{\mathcal{P}} = \mathbb{E}_{x\sim\mathcal{P}_X}[\min\{\eta(x), 1-\eta(x)\}].$$

若两类标签都有正条件概率的输入集合具有正 $\mathcal{P}_X$ 测度，这个平均便为正。即使已知分布、采用贝叶斯规则，当前输入仍会留下错误。

### 4.4.1 两类误差

相对于当前输入的贝叶斯风险，学习结果多出的风险可分成两段：限制候选空间使最低风险升高，算法在这个空间中的实际选择再使风险偏离类内最低值。

第一段称为**近似误差**（approximation error），等于类内最低期望风险减去贝叶斯风险。它由候选空间决定；固定空间后，即使拥有无限数据并能找到类内最优者，也不能因此消除该差距。

第二段通常称为**估计误差**（estimation error），等于输出的期望风险减去类内最低期望风险。对任意算法，它更准确地表示类内超额风险，还可能包含优化未完成、正则化改变目标或不一致选解的影响。对 ERM、近似 ERM 或另有一致性保证的算法，才能将相应上界主要解释为有限样本的统计估计代价。

对恰当输出 $\hat{h} = A(S) \in \mathcal{H}$，在贝叶斯风险与输出风险之间加入类内下确界，便得

$$R_{\mathcal{P}}(\hat{h}) - R^{\star}_{\mathcal{P}} = \left(\inf_{h \in \mathcal{H}} R_{\mathcal{P}}(h) - R^{\star}_{\mathcal{P}}\right) + \left(R_{\mathcal{P}}(\hat{h}) - \inf_{h \in \mathcal{H}} R_{\mathcal{P}}(h)\right). \tag{4.17}$$

第一项是近似误差，第二项是估计误差。$\mathcal{H} \subseteq \mathcal{H}_{\text{all}}$ 使第一项非负，$\hat{h} \in \mathcal{H}$ 使第二项非负。允许空间外输出时，它可以优于 $\mathcal{H}$ 的下确界，第二项便可能为负，原非负分解的解释也须相应改变。

取一个教学数值例子：贝叶斯风险 5%，阈值空间最低风险 12%，所学阈值风险 15%。表达限制贡献 7 个百分点，类内选择贡献 3 个百分点，总共高于贝叶斯风险 10 个百分点。具有一致性保证的算法可用更多数据缩小第二段的统计部分，始终返回坏假设的算法却不会自动改善。第一段的 7 个百分点还须通过改变输入表示或扩大假设空间处理。

图 4.3沿风险增大的方向排列这三个水平。贝叶斯风险到类内最低风险的距离是近似误差，类内最低风险到输出风险的距离是估计误差。后一个距离的来源仍取决于算法；只有结合 ERM、近似 ERM 或其他一致性保证，才能用有限样本代价解释其上界。

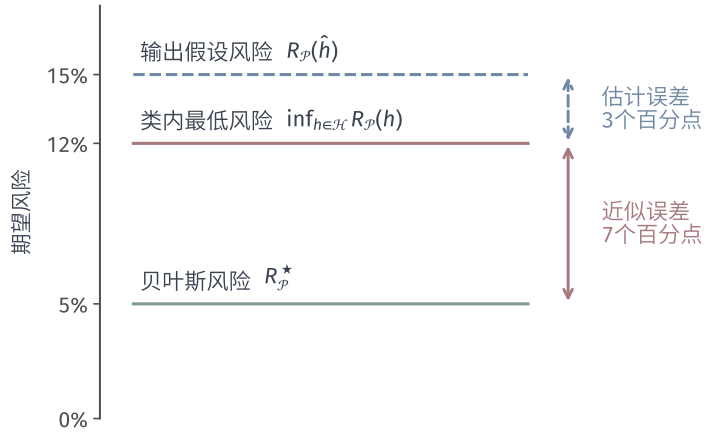


图 4.3　风险的两段差距。教学设定中，贝叶斯风险为 5%，阈值空间最低风险为 12%，输出风险为 15%。前两者相差 7 个百分点，为实线表示的近似误差；后两者相差 3 个百分点，为虚线表示的估计误差。

扩大候选空间提供了更多逼近目标的机会，也提供了更多偶然拟合样本的机会。**偏差与复杂度的权衡**（bias–complexity trade-off）指的就是二者之间的选择：“偏差”在这里表示空间的表达限制，“复杂度”表示有限样本中可靠选解的统计代价。

若正类由两个分离区间组成，单阈值的近似误差不会因数据无限增加而消失。允许许多小区间以后，空间可以表达这些正类，也可以紧密包围训练点；未见间隙仍可能被误判，类内选择的统计误差便更难控制。式 (4.17)的两项随空间一起变化，最终风险未必下降。结构风险最小化将据此比较拟合收益是否足以补偿新增的不确定性。

算法对训练目标的求解差距还须单列。若样本上最好候选错 2 封、返回者错 5 封，多出的 3 次错误来自经验目标未达到最优。**经验优化误差**（empirical optimization error）以经验风险之差计量：

$$\Delta_{\mathrm{opt}}(S) = \hat{R}_S(\hat{h}) - \inf_{h \in \mathcal{H}} \hat{R}_S(h) \geq 0, \tag{4.18}$$

它比较样本目标，与式 (4.17)的期望风险差不同，不能把二项恒等式直接变成三个非负期望风险差。须先用泛化控制连接经验与总体，再让 $\Delta_{\mathrm{opt}}(S)$ 进入输出风险保证。

### 4.4.2 用验证集选择模型

若嵌套的空间逐渐扩大且每次精确最小化经验风险，训练误差只能持平或下降。这种下降无法单独判断未来误差，可以用不参与参数拟合的**验证集**比较复杂度或其他超参数。第 1.4.3节说明训练、验证、测试各自的操作边界。候选越多，偶然低估的验证误差越容易被选中，最终评价因而需要覆盖“调参并选择模型”的整个流程（可参考第一卷“随机变量”章的“估计误差与效率”一节）。

图 4.4以教学曲线示范：训练误差继续下降时，验证误差可以回升，所选复杂度由最低验证误差确定。实际曲线未必只有一个谷底。验证数据已用于选择，故锁定模型及超参数后还须以独立测**试集**评价最终结果。若继续按测试误差改模型，测试数据也参与了选择，就失去这次独立评价的含义。

### 4.4.3 结构风险最小化

把候选空间写成 $\mathcal{H}_1 \subseteq \mathcal{H}_2 \subseteq \cdots$，例如 $\mathcal{H}_k$ 允许至多 $k$ 个区间的并作为正类区域。纯粹比较最小经验风险会偏向更丰富的空间，因为它至少保留前一空间的所有候选；只选最简单的空间，又可能留下较大的近似误差。我们因此需要一条同时考虑表达限制与有限样本选择代价的规则。

**结构风险最小化**（structural risk minimization, SRM）以带惩罚的经验目标选择空间，因为近似与估计误差依赖未知分布，不能直接最小化。先固

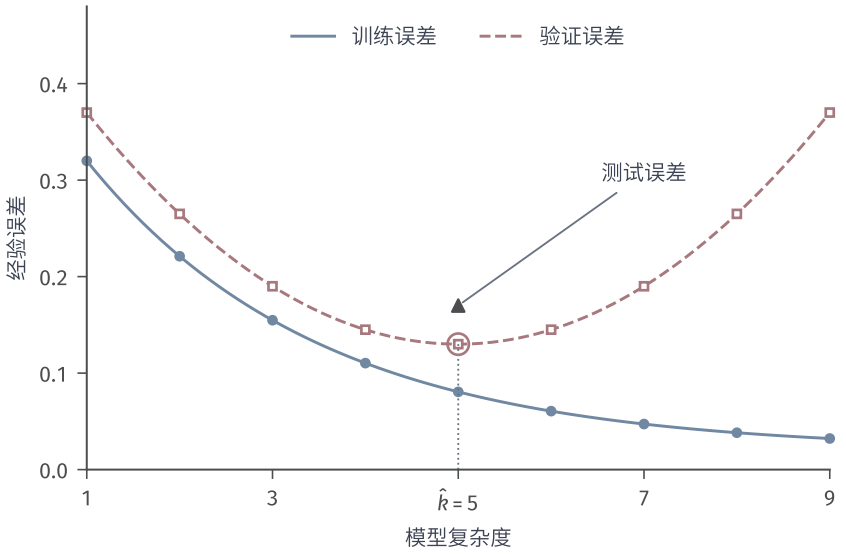


图 4.4 教学示意中的验证选择与独立测试。实线圆点为训练误差，虚线方块为验证误差，圆环的最低验证误差确定 $\hat{k}$。三角形仅为锁定模型后的一次测试评价，未参与选择，故不连成测试曲线。所有数值均为构造示意。

定总失败预算 $\delta$，分配与样本无关的 $\delta_k > 0$、$\sum_{k\ge 1}\delta_k \le \delta$。以 $\mathrm{pen}(k,n,\delta_k)$ 记录第 $k$ 个空间的复杂度惩罚，选择

$$(\hat{k},\hat{h}) \in \operatorname*{arg\,min}_{k\ge 1,\, h\in\mathcal{H}_k} \left\{ \hat{R}_S(h) + \mathrm{pen}(k,n,\delta_k) \right\}. \tag{4.19}$$

经验项衡量训练拟合，惩罚控制由样本推断总体的不确定性，通常随空间复杂度增加。它是估计误差的控制量，并非该误差本身。惩罚偏小可能选中偶然拟合的复杂规则，偏大可能留下简单空间的表达偏差。最小值不可达时，可采用带惩罚目标的近似最优解。

同时比较空间，需要同时有效的偏差保证。每个空间单独失败概率不超过 $\delta$，并不保证看过数据再选空间的总失败概率仍不超过 $\delta$。预先分配 $\delta_k$ 并令 $\sum_k \delta_k \le \delta$ 后，并集界就控制了至少一项估计失准的概率。因此以至少 $1-\delta$ 的概率，所有空间同时满足各自的偏差要求。

**定理 4.10 结构风险最小化的期望风险保证** 设 $\mathcal{H}_1 \subseteq \mathcal{H}_2 \subseteq \cdots$ 是预先给定的非空假设空间，损失为零一损失，训练样本 $S \sim \mathcal{P}^n$。固定 $\delta \in (0,1)$，选择与样本无关的 $\delta_k > 0$，满足 $\sum_{k\ge 1}\delta_k \le \delta$。假设非负惩罚 $p_k = \mathrm{pen}(k,n,\delta_k)$ 使每个假设空间都满足

$$\mathbb{P}_{S\sim\mathcal{P}^n}\left( \sup_{h\in\mathcal{H}_k} |R_{\mathcal{P}}(h) - \hat{R}_S(h)| > p_k \right) \le \delta_k. \tag{4.20}$$

这里假定相关事件可测，且惩罚在观察样本前已经确定。

若学习算法输出 $\hat{h} \in \mathcal{H}_{\hat{k}}$，并将带惩罚的经验目标求解到给定容差 $\rho \geq 0$，即

$$\hat{R}_S(\hat{h}) + p_{\hat{k}} \leq \inf_{k \geq 1,\, h \in \mathcal{H}_k} \{\hat{R}_S(h) + p_k\} + \rho, \tag{4.21}$$

则以至少 $1-\delta$ 的概率，

$$R_{\mathcal{P}}(\hat{h}) \leq \inf_{k \geq 1} \left\{ \inf_{h \in \mathcal{H}_k} R_{\mathcal{P}}(h) + 2p_k \right\} + \rho. \tag{4.22}$$

精确最小化带惩罚的经验风险时取 $\rho = 0$。若每个假设空间的这些偏差概率界对所有允许分布都使用同一组惩罚成立，则结论也对这些分布统一成立。

**证明** 先把各空间的偏差保证合在一个共同事件中，再在事件内比较输出与任意参照假设。

令 $E_k$ 表示 $\mathcal{H}_k$ 中全部 $h$ 满足 $|R_{\mathcal{P}}(h) - \hat{R}_S(h)| \leq p_k$ 的事件，令 $E = \bigcap_{k \geq 1} E_k$。并集界把至少一个空间失准的概率控制为

$$\mathbb{P}(E^{\mathrm{c}}) = \mathbb{P}\left( \bigcup_{k \geq 1} E_k^{\mathrm{c}} \right) \leq \sum_{k \geq 1} \mathbb{P}(E_k^{\mathrm{c}}) \leq \sum_{k \geq 1} \delta_k \leq \delta.$$

事件都由同一份样本决定，无需相互独立。已有 $\delta_k$ 预算便给出 $\mathbb{P}(E) \geq 1 - \delta$。

固定 $S \in E$ 后，偏差界也覆盖数据选出的空间 $\mathcal{H}_{\hat{k}}$ 及输出 $\hat{h}$，因此

$$R_{\mathcal{P}}(\hat{h}) \leq \hat{R}_S(\hat{h}) + p_{\hat{k}}.$$

以任意 $k$ 及 $h \in \mathcal{H}_k$ 作参照，带惩罚目标的近似最优性给出

$$\hat{R}_S(\hat{h}) + p_{\hat{k}} \leq \hat{R}_S(h) + p_k + \rho.$$

对同一参照，$E$ 又保证 $\hat{R}_S(h) \leq R_{\mathcal{P}}(h) + p_k$。合并这三次比较，得到

$$R_{\mathcal{P}}(\hat{h}) \leq R_{\mathcal{P}}(h) + 2p_k + \rho.$$

第一个 $p_k$ 来自参照目标的显式惩罚，第二个来自参照经验风险与总体风险的偏差。它们共同上界控制空间选择的统计代价，并非估计误差的定义值；输出空间的 $p_{\hat{k}}$ 已经在带惩罚比较中消去。

> 任意 $h \in \mathcal{H}_k$ 与任意 $k$ 都满足上式，依次取两层下确界即得式 (4.22)，无需最优假设或空间实际存在。由于全程在 $E$ 内推导，而 $\mathbb{P}(E) \geq 1-\delta$，得到所需高概率结论。 ■

算法只能计算带惩罚的经验目标，定理却允许它与各空间的最低期望风险加统计代价比较。这类结果称为**预言机不等式**（oracle inequality）：参照选择好像知道各空间的总体风险，实际算法仍只使用样本。这里引入预言机的是评价基准，没有增加训练可见信息。

可用望远镜求和分配预算：取 $\delta_k = \delta/[k(k+1)]$，因 $1/[k(k+1)] = 1/k - 1/(k+1)$ 而总和为 $\delta$。若各 $\mathcal{H}_k$ 有限，第 5.2节的一致收敛界给出

$$p_k = \sqrt{\frac{\log(2|\mathcal{H}_k|/\delta_k)}{2n}} = \sqrt{\frac{\log(2|\mathcal{H}_k|) + \log(k(k+1)/\delta)}{2n}}.$$

$|\mathcal{H}_k|$ 计入类内选择代价，$\delta_k$ 还计入跨空间比较代价。无限空间须另用容量工具建立式 (4.20)，不可把无限基数直接代入有限空间的计数公式。

从式 (4.22)两侧减去贝叶斯风险，每个参照项就成为该空间的近似误差加 $2p_k$，另有求解容差 $\rho$。$2p_k$ 上界控制选择的统计代价，不等于估计误差本身。小空间可能留下大偏差，大空间通常需要大统计项；定理用其中最小的总和控制输出风险。它既未承诺零风险，也未提供带惩罚目标的高效求解程序。

## 4.5 研究内容

PAC、不可能性与模型选择已经说明统计保证要同时指定什么信息和什么风险。后续理论又改变标签、损失、算法与环境，所需条件随之扩展。下面沿分析对象的变化梳理研究历史，再把正在研究的问题放入共同地图，以便识别各条路线分别补上了哪项条件。

### 4.5.1 发展历史

先看固定规则与数据选出的规则有何区别。统计推断研究有限样本、估计误差与重复抽样；模式识别和人工智能还要求算法从许多候选中选择预测规则。一条预先固定规则的经验频率收敛，并不自动保证看过数据后选出的规则同样可靠。学习理论因而需要分析这种选择新增的偏差，而不只研究一个固定估计量。

Vapnik 与 Chervonenkis 将有限输入上的划分数与经验频率一致逼近总体概率联系起来[4]。计数把候选函数类的丰富程度变成可分析条件，概率界则控制同一份样本对整个类的评价偏差。二者结合形成了 VC 维与一致收敛的分类框架，使风险保证能够覆盖数据选出的分类器。

Valiant 在 1984 年以 PAC 学习明确算法、样本量、误差与失败概率的量词关系，同时要求关注多项式样本量及运行时间[5]。评价于是从极限收敛推进到允许问题族上的统一有限样本保证。围绕这一标准，有限空间、VC 维、ERM 与样本复杂度相互联系，统计学习器存在、程序可计算和程序高效也逐步成为分别研究的要求。

这些参数给“学会”提供了可比较的口径：精度限定风险偏离，置信参数限定失败机会，样本复杂度计算满足二者所需的观测数。量词顺序仍决定标准强弱。每个分布各配一个算法，不等于同一算法覆盖全部分布。本章前面的 PAC 定义保留了后一种统一要求。

在这套口径下，少量样本足以辨认低风险规则，并不自动提供找到规则的高效程序；迅速降低训练损失，也不自动降低期望风险。计算学习理论因此分析表示、查询、归约与运行时间，分别核对信息是否足够及程序能否利用信息。非凸优化、大规模训练和组合输出问题仍会遇到这两项不同的限制。

当评价涉及实值预测与替代损失时，二元划分计数不足以记录函数值的变化。Rademacher 复杂度用随机符号检验函数类在样本上的拟合能力[6]。伪维、胖打散维与覆盖数则从不同角度推广容量控制。样本压缩改问能否以少量代表观测和有限旁信息重构预测规则[7]。多分类进一步显示，一致收敛、一般可学习性及具体 ERM 样本复杂度可受不同维度控制，标签结构与输出范围必须计入结论[8,9]。

这些扩展保留了原来“同时评价候选”的问题，增加了评价可利用的信息。VC 维取最坏输入集合上的二元划分丰富程度，实值函数与间隔分析还需要样本几何、预测分值或损失变化。覆盖、随机复杂度和间隔界分别在这些对象上建立控制，使研究能够在分布无关保证与更贴近数据的保证之间选择。

容量进入模型选择时，就形成经验拟合与复杂度惩罚的比较。表达不足留下近似误差，有限样本中的偶然拟合增加选择代价，经验目标未充分求解又引入优化误差。将三者分别计算，才能看清扩大模型、增加数据或改进求解各自影响哪个环节，也能连接理论界与模型、训练算法的设计。

压缩与多分类还要求核对容量工具到底提供充分条件还是完整刻画。少量代表样本可通过重构限制可传递信息，因而给出泛化保证；不同标签结构下，刻画一致收敛的维度却未必刻画全部学习器。二分类中的等价关系因此不能未经证明推广到任意输出空间[10,11,12]。

[5] L. G. Valiant, *A Theory of the Learnable* In Communications of the ACM, 1984, vol. 27, no. 11, pp. 1134–1142

[6] P. L. Bartlett, S. Mendelson, *Rademacher and Gaussian Complexities: Risk Bounds and Structural Results* In Journal of Machine Learning Research, 2002, vol. 3, pp. 463–482

[7] S. Moran, A. Yehudayoff, *Sample Compression Schemes for VC Classes* In Journal of the ACM, 2016, vol. 63, no. 3, pp. 21:1–21:10

[8] A. Daniely, S. Sabato, S. Ben-David, S. Shalev-Shwartz, *Multiclass Learnability and the ERM Principle* In Journal of Machine Learning Research, 2015, vol. 16, no. 72, pp. 2377–2404

[9] N. Brukhim, D. Carmon, I. Dinur, S. Moran, A. Yehudayoff, *A Characterization of Multiclass Learnability* In Proceedings of the 63rd Annual Symposium on Foundations of Computer Science, 2022, pp. 943–955

[10] S. Moran, A. Yehudayoff, *Sample Compression Schemes for VC Classes* In Journal of the ACM, 2016, vol. 63, no. 3, pp. 21:1–21:10

[11] A. Daniely, S. Sabato, S. Ben-David, S. Shalev-Shwartz, *Multiclass Learnability and the ERM Principle* In Journal of Machine Learning Research, 2015, vol. 16, no. 72, pp. 2377–2404

[12] N. Brukhim, D. Carmon, I. Dinur, S. Moran, A. Yehudayoff, *A Characterization of Multiclass Learnability* In Proceedings of the 63rd Annual Symposium on Foundations of Computer Science, 2022, pp. 943–955

若整个候选类很大，单看它的容量仍无法区分具体算法如何选解。算法稳定性考察删除或替换一个观测后输出的变化，Bousquet 与 Elisseeff 建立了它与泛化的联系；后续研究将这一思路用于一般学习和随机梯度下降的扰动传播[13,14,15]。信息论则分析输出对训练数据的依赖，以互信息、条件互信息及换测度工具控制期望泛化差[16]。两条路线都把算法实际使用样本的方式纳入保证。

固定同一个函数空间，正则化 ERM、随机梯度下降和其他选解规则可能对样本替换作出不同反应。稳定性把这种反应保留在分析中，限制单个观测的偶然性怎样影响预测。不过，始终返回同一决策也可以稳定，风险却可能很高。稳定性必须结合经验优化或风险基准，才能支持学习成功的结论。

信息论以互信息、相对熵等量记录这种数据依赖。普通互信息衡量输出与整份样本的平均联系，条件互信息在预先抽取的双样本上记录输出透露了哪些选择；压缩长度与有限输出范围还能提供信息量上界。这类分析通常先控制期望泛化差。转成 PAC 的高概率保证时，还须另加集中、尾界或期望到概率的转换。

显式正则化、样本顺序、随机初始化与提前停止，都能改变同一函数空间中的选解。容量界若只记录空间，就无法呈现这些差别；稳定性与信息量则分别记录算法的样本敏感性及输出保留的数据依赖。研究复杂度的对象由此从候选函数类扩展到算法的行为。

扩展分析对象也要限制结论。很少利用数据的算法可能既稳定又低互信息，却没有学好任务。控制数据依赖只能回答泛化偏离，还需经验拟合、近似能力与比较基准才能判断总风险。深度学习理论同样须分开分析表示形成、优化成功与最终风险，不能让一个依赖量承担全部解释。

这种分析需要保留相应训练条件。容量通常在训练前给出，稳定性与信息依赖却还受随机化方式、运行步数及输出规则影响。初始化、样本顺序、轨迹与停止规则因此成为区分训练过程的材料。后续网络理论据此研究优化轨迹、参数分布和表示变化，使复杂度随模型空间与训练过程共同确定。

[13] O. Bousquet, A. Elisseeff, *Stability and Generalization* In Journal of Machine Learning Research, 2002, vol. 2, pp. 499–526

[14] S. Shalev-Shwartz, O. Shamir, N. Srebro, K. Sridharan, *Learnability, Stability and Uniform Convergence* In Journal of Machine Learning Research, 2010, vol. 11, no. 90, pp. 2635–2670

[15] M. Hardt, B. Recht, Y. Singer, *Train Faster, Generalize Better: Stability of Stochastic Gradient Descent* In Proceedings of the 33rd International Conference on Machine Learning, 2016, pp. 1225–1234

[16] A. Xu, M. Raginsky, *Information-Theoretic Analysis of Generalization Capability of Learning Algorithms* In Advances in Neural Information Processing Systems, 2017

现代网络甚至可以拟合随机标签，因此表达能力和参数数量不能单独解释为何某次训练能泛化[17]。分析转向所选解的权重范数与间隔、初始化附近的神经切线核、梯度下降的隐式偏差、宽网络平均场及参数分布的PAC–Bayes 界[18,19,20]。函数、轨迹与参数分布各保留不同信息，分别服务于表示、优化、选解与泛化这些相关而不同的问题。

过参数化模型也可能在近零训练误差后，随规模增加出现测试风险再下降。线性插值中的良性过拟合结果表明，协方差谱、噪声及最小范数选解满足特定条件时，可以控制这类风险[21,22]。因此“参数必须少于样本”不能作为普遍标准，原始参数数目还未记录数据几何、优化偏好与有效自由度。需要判断的是哪类插值解能够控制噪声、保留推广所需结构。

各条网络路线的对象与条件仍不同。神经切线核在初始化邻域中以初始梯度所决定的核近似网络；隐式偏差考察无显式正则化时优化偏向哪些解；平均场研究宽度增加时参数分布的演化；PAC–Bayes 比较数据相关参数分布与预定参照分布。它们可在特定模型上相互印证，结论却须各按条件使用。显著特征学习离开初始化邻域时，局部线性化结果尤其不能直接沿用。

预训练又增加了下游学习的前置经验。语料、架构、目标与优化共同决定初始表示，下游样本继续调整，推理还可能由上下文示例与额外计算改变。下游风险因而同时反映预训练覆盖、表示充分性、适应方法与评价协议。只数微调参数不足以分辨这些贡献，分析须分别追踪预训练、迁移和推理阶段提供了什么信息。

训练与评价来源改变后，领域自适应和领域泛化要求重新连接两个环境。分布差异、覆盖、共享标签机制与共同错误等条件提供这种联系；缺少联系时，即使假设空间很小也可能无法识别目标标签[23,24]。这个问题与因果可识别性、时间依赖、在线动态比较及鲁棒优化的允许集合发生交叉。

估计源域与目标域的输入差异，只能说明可见分布相差多少，无法决定目标标签。若支持缺少覆盖或同一输入跨环境改变标签，无标签目标数据便可能同时符合两种要求相反预测的来源。迁移分析须先建立可识别联系，再计算有限样本代价；更精确的差异估计仍无法填补标签信息缺口。

多环境训练、持续变化与测试时适应进一步改变了数据关系。环境之间提供辨别信息时，多源观测可能区分偶然相关与稳定关系；在线更新可利用近期数据；交互收集还会随模型输出改变可见样本与评价分布。此时须说明环境生成、保持的机制及变化的可识别条件，不能只给固定分布风险附加一个误差项。

这些扩展共同保留了最初的预测问题：固定规则发展到候选类，样本保证加上计算要求，最坏容量补充算法选解，同分布风险推广到环境可识别性。后来的工具继续使用前面的条件，同时更细地规定数据来源、可见信

[17] C. Zhang, S. Bengio, M. Hardt, B. Recht, O. Vinyals, *Understanding Deep Learning (Still) Requires Rethinking Generalization* In Communications of the ACM, 2021, vol. 64, no. 3, pp. 107–115

[18] A. Jacot, F. Gabriel, C. Hongler, *Neural Tangent Kernel: Convergence and Generalization in Neural Networks* In Advances in Neural Information Processing Systems, 2018

[19] D. Soudry, E. Hoffer, M. S. Nacson, S. Gunasekar, N. Srebro, *The Implicit Bias of Gradient Descent on Separable Data* In Journal of Machine Learning Research, 2018, vol. 19, no. 70, pp. 1–57

[20] A. Maurer, *A Note on the PAC Bayesian Theorem*, 2004, arXiv: cs/0411099

[21] M. Belkin, D. Hsu, S. Ma, S. Mandal, *Reconciling Modern Machine-Learning Practice and the Classical Bias–Variance Trade-Off* In Proceedings of the National Academy of Sciences, 2019, vol. 116, no. 32, pp. 15849–15854

[22] P. L. Bartlett, P. M. Long, G. Lugosi, A. Tsigler, *Benign Overfitting in Linear Regression* In Proceedings of the National Academy of Sciences, 2020, vol. 117, no. 48, pp. 30063–30070

[23] S. Ben-David, J. Blitzer, K. Crammer, A. Kulesza, F. Pereira, J. W. Vaughan, *A Theory of Learning from Different Domains* In Machine Learning, 2010, vol. 79, pp. 151–175

[24] S. Ben-David, T. Lu, T. Luu, D. Pál, *Impossibility Theorems for Domain Adaptation* In Proceedings of the Thirteenth International Conference on Artificial Intelligence and Statistics, 2010, pp. 129–136

息、比较基准与概率对象。接下来讨论的前沿问题也沿这些分别建立的关系展开。

### 4.5.2 当前前沿

图 4.5从有限经验何时支持推广这一总问题出发，按问题与信息、泛化机制、实现与扩展分成三组，再列出八个相互制约的问题及部分代表课题。下面据此考察正在发展的方向，并指出已有条件尚不足以回答哪些问题。

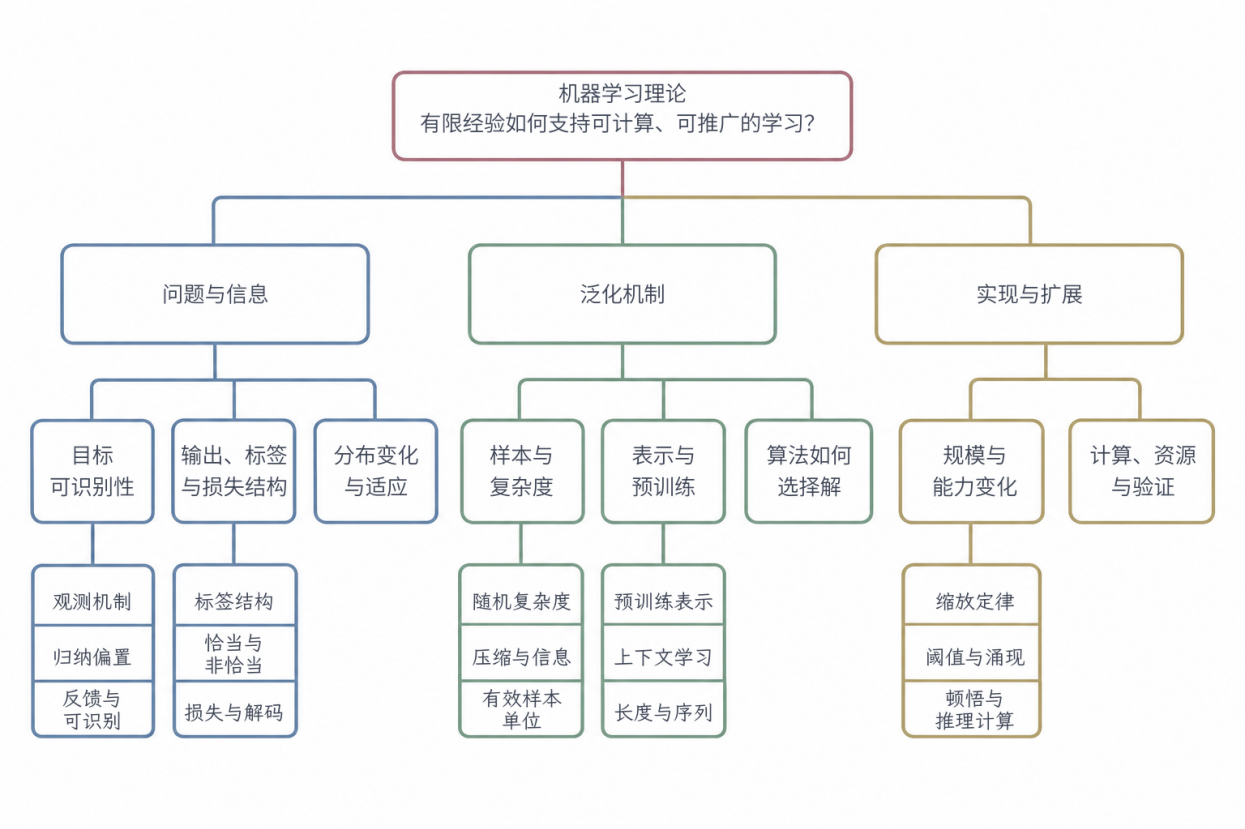


图 4.5　学习理论的问题与条件地图。顶层询问有限经验怎样支持可计算且可推广的学习；下方以蓝、绿、黄区分问题与信息、泛化机制、实现与扩展三组，这三组共列八个相互制约的问题。末端列表给出部分代表课题，不表示完整分类；连线表示讨论层次，不表示推导或因果关系。

**数据与算法相关的泛化解释** 当候选类的最坏容量远大于样本量，一致上界可能有效却宽到无法解释实际选解。研究于是考察间隔、范数、压缩、稳定性、信息依赖、参数后验与完整轨迹，以记录训练真正到达的结果。这些量本身也可能由训练数据选定，并随参数化和优化器改变；小数值只有连同选择过程的概率依赖一起受控，才支持泛化判断。

语言模型还需要先明确样本单位。文档、序列、词元与窗口通常有依赖，按独立样本累计词元可能高估有效信息。近期研究在明确损失与置信条件下，利用参数后验或数据分解得到严格低于对应平凡上界的泛化界[25,26]。它们仍依赖条件独立性、先验与数据选择。数值有用、条件可检验且能预测算法干预的风险界，仍需同时满足这些要求。

小泛化指标还可能只表现为相关。平坦性、频谱或稳定性与测试风险共同变化，并未自动解释改变初始化、样本顺序或时长的后果。把终点参数与训练动力学联系起来，需要理论对受控干预后的选解及风险作出可检验预测，而不只拟合已有结果。

**预训练、上下文学习与表示迁移** 冻结预训练表示减少了优化自由度，也可能遗漏目标信息；开放更多参数增加了可调整的自由度，可能改善任务适应，也可能增加下游依赖与遗忘。变化的方向和幅度须随表示、任务、数据和优化条件判断。因此预训练后的样本复杂度不能只按可训练参数计算，参数效率与统计效率也须分别衡量。分析需要量化预训练经验、表示选择及下游标签各提供多少任务信息。

上下文学习让参数不变的模型仍能根据提示示例调整预测，训练与使用便不再只由参数更新区分。受控理论可以将它分析为隐式贝叶斯推断，或把 Transformer 作为执行某类学习算法的对象[27,28]。这类解释均须给定预训练分布、上下文生成及任务族，不能由特定模型中的机制推断任意基础模型都遵循它。

上下文示例的顺序、相互依赖及新增示例引起的注意力或输出长度变化，还会改变评价条件。稳定性与非独立同分布分析尝试控制替换及依赖，长度泛化则研究训练长度之外的规则保持[29,30]。表示、算法模拟与序列外推因而相互联系。推进到真实系统时，预训练语料不透明且适应可能由多种机制共同产生，受控解释仍须检验其适用范围。

[25] S. Lotfi, M. A. Finzi, Y. Kuang, T. G. J. Rudner, M. Goldblum, A. G. Wilson, *Non-Vacuous Generalization Bounds for Large Language Models* In Proceedings of the 41st International Conference on Machine Learning, 2024, pp. 32801–32818

[26] S. Lotfi, Y. Kuang, B. Amos, M. Goldblum, M. Finzi, A. G. Wilson, *Unlocking Tokens as Data Points for Generalization Bounds on Larger Language Models* In Advances in Neural Information Processing Systems, 2024

[27] S. M. Xie, A. Raghunathan, P. Liang, T. Ma, *An Explanation of In-context Learning as Implicit Bayesian Inference* In International Conference on Learning Representations, 2022

[28] Y. Li, M. E. Ildiz, D. Papailiopoulos, S. Oymak, *Transformers as Algorithms: Generalization and Stability in In-context Learning* In arXiv preprint arXiv:2301.07067, 2023

[29] Y. Wang, Y. Zhou, S. Fu, Y. Chen, Y. Jing, L. Rutkowski, D. Tao, *Towards a Theoretical Understanding of In-context Learning: Stability and Non-I.I.D Generalisation* In International Conference on Learning Representations, 2026

[30] X. Huang, A. Yang, S. Bhattamishra, Y. Sarrof, A. Krebs, H. Zhou, P. Nakkiran, M. Hahn, *A Formal Framework for Understanding Length Generalization in Transformers* In International Conference on Learning Representations, 2025

**统计、计算与可验证性的统一** 达到样本复杂度下界的阶，也不能保证训练、预测、存储或通信可承受。理论若调用优化预言机、独立采样器或无限精度运算，实现时就要补计有限迭代、随机误差、精度与停止条件。联合样本、时间、内存和通信预算的分析，正是将统计存在性落实到资源受限算法所需的步骤。

范数、覆盖常数、稳定性或分布差异等条件，若依赖未知总体，使用者就难以直接确认当前系统是否满足。将它们转成可检查证据，需要区分不可观测假设与可由日志、独立数据、重复运行或干预验证的条件，并核算验证本身的样本及资源成本。

**规模规律、能力变化与测试时计算** 大模型实验同时增加参数、数据与计算时，**缩放定律**（scaling law）以经验曲线记录资源与测试损失的关系，辅助预算分配[31,32]。曲线先描述已测范围，不能自动保证外推。数据重复、优化残差、模型形状或评价污染均可改变它；多种资源同步增长时，仅靠拟合也难分辨主导机制。

若要解释这种曲线，须区分近似、估计、优化与特征学习可能产生的相似幂律，再预测数据谱、训练时长或形状改变的后果。阈值化评价也可能制造能力突现，**顿悟**（grokking）则可能涉及特征形成、隐式偏差及测量尺度[33,34,35]。能再现曲线尚不足以辨认机制，新的可区分实验预测才提供进一步证据。

推理中的采样、搜索与验证使计算预算从训练延伸到使用。某些任务和策略增加测试时计算可以改善结果，收益却仍由候选生成、选择器及预算共同决定[36]。模型变大与同一模型搜索更久，需要分别分析对错误相关性、选择偏差及最终风险的影响。跨资源范围的外推还须保留这两类不同机制。

**变化环境中的持续学习保证** 预训练语料可能已含目标来源、相近样本或任务线索，使“未见环境”不能仅按微调数据界定。若忽略这些暴露，领域泛化评价可能把已有覆盖算成对新分布的外推[37]。因此应记录预训练来源、选模所见环境与最终测试环境，再说明哪些跨域关系能识别目标风险。

持续变化还需要将更新规则与到达数据的机制结合。被动数据流由外部环境继续生成；推荐和控制中的输出却可影响下一批可见数据。测试时适应的无标签代理目标可能随变化失效，更新流也可能被操纵。恢复复杂度研究达到规定性能所需的代价[38]。变化下的共形方法研究协变量与后验同时漂移时的覆盖[39]。变化范围、反馈与加权误差都是这些结论的条件，原交换性保证不能直接延用。

这些设定共同要求处理时间依赖及自适应交互。可用保证还需联合控制检测延迟、更新稳定性、历史任务退化与恢复时间，并规定停止或回退

[31] J. Kaplan, S. McCandlish, T. Henighan, T. B. Brown, B. Chess, R. Child, S. Gray, A. Radford, J. Wu, D. Amodei, *Scaling Laws for Neural Language Models* In arXiv preprint arXiv:2001.08361, 2020

[32] J. Hoffmann, S. Borgeaud, A. Mensch, et al., *Training Compute-Optimal Large Language Models* In arXiv preprint arXiv:2203.15556, 2022

[33] B. Bordelon, A. Atanasov, C. Pehlevan, *How Feature Learning Can Improve Neural Scaling Laws* In International Conference on Learning Representations, 2025

[34] R. Schaeffer, B. Miranda, S. Koyejo, *Are Emergent Abilities of Large Language Models a Mirage?* In Advances in Neural Information Processing Systems 36, 2023

[35] A. Power, Y. Burda, H. Edwards, I. Babuschkin, V. Misra, *Grokking: Generalization Beyond Overfitting on Small Algorithmic Datasets* In arXiv preprint arXiv:2201.02177, 2022

[36] C. Snell, J. Lee, K. Xu, A. Kumar, *Scaling LLM Test-Time Compute Optimally Can be More Effective than Scaling Parameters for Reasoning* In International Conference on Learning Representations, 2025

[37] P. Mayilvahanan, R. S. Zimmermann, T. Wiedemer, E. Rusak, A. Juhos, M. Bethge, W. Brendel, *In Search of Forgotten Domain Generalization* In Proceedings on “I Can’t Believe It’s Not Better: Challenges in Applied Deep Learning” at ICLR 2025 Workshops, 2025, pp. 90–130

[38] Z. Zhou, M. Yang, S.-Y. Tian, K.-Y. Yu, L.-Z. Guo, Y.-F. Li, *On the Learnability of Test-Time Adaptation: A Recovery Complexity Perspective* In arXiv preprint arXiv:2605.28057, 2026

的条件。经典可学习性由此扩展到实际算法、预算和数据过程；条件能否检查，以及失效范围能否明确，也成为分析的一部分。

## 4.6 本章小结

有限样本支持未来风险判断，首先取决于观测单位、比较与输出空间、损失、允许分布及随机来源。二分类中算法比较训练经验风险，目标却是总体期望风险。PAC 用 $\varepsilon$ 限定风险或超额风险，用 $\delta$ 限定随机训练失败概率。可实现分布有零风险目标，不可知分布允许噪声与表达限制，改以类内下确界为基准。两种设定都要求同一充分样本量覆盖全部允许分布。

低经验风险不能独自完成这项推断。自由标签空间中的没有免费的午餐下界来自未见标签信息不足，更多计算无法消除。加入假设限制可以建立输入间的联系，却可能排除所需规则。贝叶斯风险、近似误差与类内超额风险分别定位输入、空间与算法选择的贡献；经验优化误差和泛化差则比较不同的量，须保留各自基准。

后续理论在这些关系上改变分析对象：候选容量之外考察稳定性、信息依赖与网络选解，同分布之外考察环境联系与可识别性。标签结构、损失、参数化和数据来源的变化，都要重新核对表示、有限样本与计算条件。规模规律和持续适应仍受这些基础条件约束。

结构风险最小化已经给出一种连接：同时控制各空间的经验偏差，算法即可用拟合加惩罚与最佳参照空间比较。下一章将为二分类建立提供这种偏差控制的容量条件。统计样本界成立后，还须另给能停机并满足时间预算的求解程序，才能获得可计算或高效学习。

**延伸阅读** Shalev-Shwartz 与 Ben-David 的 *Understanding Machine Learning* 第 2–5 章展开 PAC、ERM 与没有免费的午餐，第 7 章讨论 SRM 及描述长度。阅读这些结果时，可核对各自比较基准及算法先于分布的量词顺序，从而判断结论适用于哪一类学习问题[40]。

Delle Rose 等的可计算 PAC 研究进一步区分统计存在与有效见证[41]。知道某种预测不可能出现，尚未给出有限时间找出它的程序。第 5.7节会以定义和例子落实这种区别，可与原文的表示及输出约定对照阅读。

[39] B. Wang, X. Qiao, *Conformal Prediction Under Generalized Covariate Shift with Posterior Drift* In Proceedings of the 28th International Conference on Artificial Intelligence and Statistics, 2025, pp. 4888–4896

[40] S. Shalev-Shwartz, S. Ben-David, *Understanding Machine Learning: From Theory to Algorithms*, Cambridge University Press, 2014, 1st ed.

[41] V. Delle Rose, A. Kozachinskiy, C. Rojas, T. Steifer, *Find a Witness or Shatter: The Landscape of Computable PAC Learning* In Proceedings of the 36th Conference on Learning Theory, 2023, pp. 511–524

第 5 章

# 二分类学习的可学习性

第 4章的阈值 0.4 与 0.6 分对同样四封训练邮件，却在分数 0.5 处回答不同。新的邮件可能落在某个候选的错误区域，从而将它排除；若候选总体上经常出错，独立抽样遗漏该区域的机会随样本增加而减小。算法却会看过样本再选假设，因此我们还须排除另一种情况：许多候选中至少一个高风险假设碰巧分对全部训练邮件。样本量分析需要同时考虑单个候选的失败概率和可被选择的候选数。

我们先对有限候选求样本量，再把计数对象改为有限输入上的不同预测，以处理实数阈值等无限空间。VC 维度量这种二元预测的丰富程度，一致收敛将其连接到风险保证。Rademacher 与高斯复杂度进一步保留样本上的函数值，压缩与集成则利用重构或组合的机制分析输出。最后还须把统计存在落实为程序，分别核对停机和训练、预测资源。

分析始终以第 4.1节的二分类设定为基线：输入标签对、i.i.d. 抽样、零一损失，以及第 4.2节的两种 PAC 量词。变化的是我们怎样控制候选与数据选解的复杂度。默认比较空间为 $\mathcal{H}$；集成或可计算构造允许空间外输出时，另行注明非恰当学习。

## 5.1 可实现的有限假设空间

先把可选阈值限为 0.2、0.4、0.6、0.8。邮件分数仍可遍历 $[0,1]$，只有候选假设数变成四个。这个有限空间使我们能够分别计算每个候选分对全部样本的概率，再合并这些事件。

若可实现性给出 $h^\star \in \mathcal{H}$ 且总体风险为零，它在有限训练样本上也几乎必然零错误。ERM 因此几乎必然可选经验风险为零者。这样的假设称为与样本**一致**（consistent），即分对这份样本的每个标签；它尚未被要求与总体真值处处相同。

一致假设仍可有大总体风险。错误概率 20% 的候选分对一封的概率为 80%，分对 $n$ 封独立邮件的概率为 $0.8^n$。只看这批样本的 ERM 无法排除

它。因此要保证最终选解可靠，需要限制任意高风险候选与样本一致的概率，单个候选的界还不够。

将 20% 推广为容限 $\varepsilon$。取 $Y=\{0,1\}$ 和 $S\sim\mathcal{P}^n$，先固定 $h\in\mathcal{H}$。若 $R_{\mathcal{P}}(h)>\varepsilon$，它分对一次观测的概率小于 $1-\varepsilon$；独立抽样使全部分对的概率连乘，得到

$$\mathbb{P}\big(\hat{R}_S(h)=0\big)=\big(1-R_{\mathcal{P}}(h)\big)^n\le(1-\varepsilon)^n\le e^{-n\varepsilon}. \tag{5.1}$$

式 (5.1)是固定假设的概率。ERM 在抽样后才选择输出，须把其失败包含在“某个高风险假设仍与样本一致”的事件中，再对所有候选使用并集界。候选可能同时通过样本检验，并集界仍有效；有限的候选数因此转化为可计算的样本量。

**定理 5.1　有限假设空间的可实现 PAC 样本量界**　设 $(X,\mathcal{X})$ 为可测空间，$Y=\{0,1\}$ 取离散 $\sigma$ 代数，$\mathcal{H}\subseteq Y^X$ 是由可测分类器组成的非空有限集合，$\mathcal{P}$ 是 $X\times Y$ 上的联合分布。采用零一损失，并记

$$R_{\mathcal{P}}(h)=\mathbb{P}_{(x,y)\sim\mathcal{P}}\{h(x)\neq y\},\qquad \hat{R}_S(h)=\frac{1}{n}\sum_{i=1}^{n}\mathbb{I}\{h(x_i)\neq y_i\}.$$

设 $n\ge 1$、$S=((x_i,y_i))_{i=1}^n\sim\mathcal{P}^n$，且存在 $h^\star\in\mathcal{H}$ 满足 $R_{\mathcal{P}}(h^\star)=0$。对任意 $\varepsilon,\delta\in(0,1)$，若可测学习算法（允许内部随机性）以概率 1 输出满足 $\hat{R}_S(\hat{h})=0$ 的 $\hat{h}\in\mathcal{H}$，则

$$\mathbb{P}_{S,A}\big(R_{\mathcal{P}}(\hat{h})>\varepsilon\big)\le|\mathcal{H}|e^{-n\varepsilon}. \tag{5.2}$$

特别地，只要

$$n\ge\frac{\log|\mathcal{H}|+\log(1/\delta)}{\varepsilon}, \tag{5.3}$$

算法就以至少 $1-\delta$ 的概率输出期望风险不超过 $\varepsilon$ 的假设；这里的概率同时来自 $S\sim\mathcal{P}^n$ 和算法的内部随机性。

**证明**　题设保证输出几乎必然与样本一致；可实现性也使这样的选解存在。输出风险若超过 $\varepsilon$，至少一个高风险候选通过了全部观测的检验。由此

$$\begin{aligned}\mathbb{P}\big(R_{\mathcal{P}}(\hat{h})>\varepsilon\big)&\le\mathbb{P}\big(\exists h\in\mathcal{H}:R_{\mathcal{P}}(h)>\varepsilon,\ \hat{R}_S(h)=0\big)\\&\le\sum_{h:R_{\mathcal{P}}(h)>\varepsilon}\mathbb{P}\big(\hat{R}_S(h)=0\big)\le|\mathcal{H}|e^{-n\varepsilon}.\end{aligned}$$

将末项限制为 $\delta$ 并解出 $n$，即得式 (5.3)。 ∎

取四阈值空间且其中有零风险成员，要求成功概率至少 99%、风险至多 5%,便是 $\delta = 0.01$、$\varepsilon = 0.05$。式 (5.3)给出充分样本量 $\lceil(\log 4+\log 100)/0.05\rceil = 120$。任何满足可实现性的数据分布都可使用这个数，独立同分布抽取 120 封后，ERM 达到该概率保证。上界并未声称 119 封或更少一定失败。

将候选从 4 个增至 8 个而固定双容限,充分上界变为 $\lceil(\log 8+\log 100)/0.05\rceil = 134$。候选翻倍只使未取整的上界增加 $\log 2/\varepsilon$。有限空间由此对任意容限都有分布统一的样本保证，即可实现 PAC 可学习。找到解需要多少计算，仍须另外核算。

上述证明利用零风险成员使 ERM 能选择样本一致者，再排除高风险者也一致的事件。标签有噪声时，各候选都可能出错，只能比较错误比例；高总体风险者仍可能碰巧少错。我们需要控制这种比例估计的偏差，才能判断训练比较是否延续到未来风险。

## 5.2 不可知的有限假设空间

为使数据选解的比较可靠，可以要求同一份样本准确评价全部候选。即使 ERM 看过数据再选，输出与参照的两次偏差比较仍能控制其超额期望风险。这种同时控制称为一致收敛。有限空间可直接逐候选求界，并支持不可知 ERM；无限类则在第 5.3节改用预测计数。

先选阈值再抽样时，所选 $h$ 固定不变，经验风险却因样本而变。对每条观测，零一损失是均值为 $R_{\mathcal{P}}(h)$ 的 Bernoulli 变量；$n$ 个损失相互独立。Hoeffding 不等式因此控制经验错误比例的偏差：

$$\mathbb{P}\left(\left|\hat{R}_S(h) - R_{\mathcal{P}}(h)\right| > \eta\right) \le 2e^{-2n\eta^2}. \tag{5.4}$$

式 (5.4)尚未覆盖抽样后选择的 $A(S)$。若同时检验四个阈值，ERM 根据四个经验风险选择输出；只保证其中一个阈值估计准确，仍可能选中另一个偏差较大的阈值。若四者的偏差都不超过 $\eta$，输出风险就至多比类内最低风险高 $2\eta$：输出自身的偏差用去一个 $\eta$，参照假设的偏差再用去一个 $\eta$。后文将证明这两次比较。图 5.1以竖线显示各自偏差；全部竖线受控时，样本选出的输出也受控。

图中的竖线表示各候选的估计偏差。固定容限 $\eta$，图中全部候选的风险差都不超过它，才算这份样本同时估得准。我们要找一个统一邮件数，使独立抽样得到这种共同事件的概率至少 $1-\delta$，而不按未知邮件与标签分布另定样本量。下面把这个共同估计要求写成概率条件。

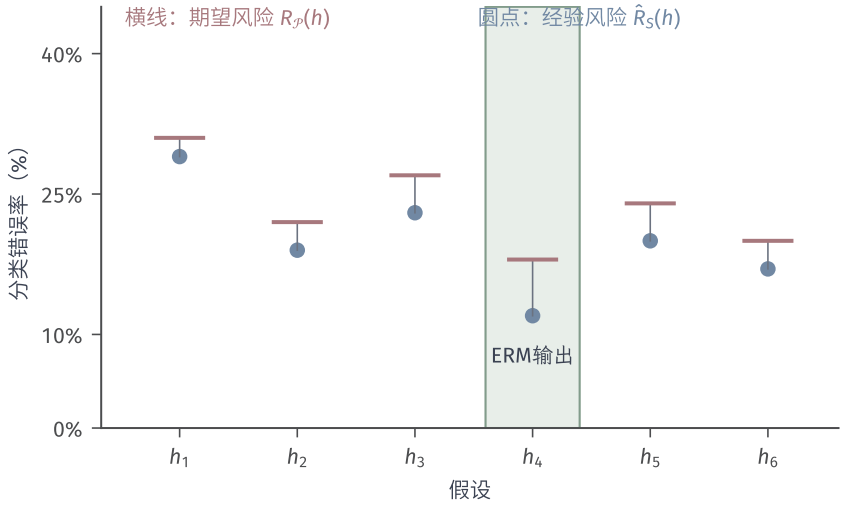


图 5.1 单个风险估计与共同保证。竖线连接各假设的经验风险与期望风险；只限制其中一条线，不能覆盖 ERM 在框中选择的输出。限制全部竖线后，这个数据依赖输出也落在保证内。

**可测性与可分性约定** 有限类的上确界是有限个可测随机变量的最大值。无限类则须处理整个零一损失函数类

$$\mathcal{F}_{01} = \{(x,y) \mapsto \ell_{01}(h(x),y) : h \in \mathcal{H}\}$$

本章采用第 4.1节给出的可测性与可分性条件，使相关上确界和比较事件可测。压缩、重构与学习器的数据依赖映射也须可测。可实现样本可选与它一致的成员，其他存在性论证采用该约定中的可测近似 ERM；缺少这些条件时，以下结论不能直接沿用。

这里对零一损失类 $\mathcal{F}_{01}$ 使用**一致收敛**（uniform convergence）：一份样本须同时估准全部候选的风险，而且充分样本量必须统一适用于所有允许的联合分布（可参考第一卷“随机变量”章的一致收敛定义）。对任意 $\eta,\delta \in (0,1)$，记一个只依赖 $\mathcal{H},\eta,\delta$ 的充分门槛为 $m_{\mathcal{H}}^{\mathrm{UC}}(\eta,\delta)$；在第 4.1节的可测性与可分性约定下，任意 $\mathcal{P}$ 及 $n \geq m_{\mathcal{H}}^{\mathrm{UC}}(\eta,\delta)$ 应满足

$$\mathbb{P}_{S\sim\mathcal{P}^n}\left(\sup_{h\in\mathcal{H}} |\hat{R}_S(h) - R_{\mathcal{P}}(h)| \leq \eta\right) \geq 1-\delta. \tag{5.5}$$

式 (5.5)的上确界覆盖 $\mathcal{H}$ 中全部风险差，不必由某个假设取到。它不超过 $\eta$，就表示每个候选在这份样本上估得准；对整批抽样的概率保证允许少数样本失准。$\mathcal{P}$ 是输入与标签的联合来源，包含输入频率及条件标签规律，不只是 $\mathcal{P}_X$。各总体风险可以随分布改变，充分样本量 $m_{\mathcal{H}}^{\mathrm{UC}}(\eta,\delta)$ 须保持统一。这项估计要求不需要零风险成员，故涵盖不可知设定，分布无关的范围与定义 4.4相同。

一致收敛评价的是风险估计，而非风险大小。高风险候选若在样本上也表现为高风险，仍符合估计准确的要求。

有限空间的共同偏差事件等价于没有候选的风险差超过 $\eta$。式 (5.4)先控制一个固定候选失准的概率，将这些有限个概率相加，就控制了至少一个候选失准的事件。

**定理 5.2　有限假设空间的一致收敛样本量界**　设 $(X, \mathcal{X})$ 为可测空间，$Y = \{0, 1\}$ 取离散 $\sigma$ 代数，$\mathcal{H} \subseteq Y^X$ 是由可测分类器组成的非空有限集合，$\mathcal{P}$ 是 $X \times Y$ 上的任意联合分布。对零一损失，记

$$R_{\mathcal{P}}(h) = \mathbb{P}_{(x,y)\sim\mathcal{P}}\{h(x) \neq y\}, \qquad \hat{R}_S(h) = \frac{1}{n}\sum_{i=1}^{n} \mathbb{I}\{h(x_i) \neq y_i\}.$$

设 $n \geq 1$ 且 $S = ((x_i, y_i))_{i=1}^n \sim \mathcal{P}^n$。对任意 $\eta, \delta \in (0, 1)$，只要样本量满足

$$n \geq \frac{\log(2|\mathcal{H}|/\delta)}{2\eta^2}, \tag{5.6}$$

就有

$$\mathbb{P}_{S\sim\mathcal{P}^n}\left(\sup_{h\in\mathcal{H}} |\hat{R}_S(h) - R_{\mathcal{P}}(h)| \leq \eta\right) \geq 1 - \delta.$$

同一概率界也可写为：对任意 $n \geq 1$ 和 $\delta \in (0, 1)$，以下不等式以至少 $1 - \delta$ 的概率成立：

$$\sup_{h\in\mathcal{H}} |\hat{R}_S(h) - R_{\mathcal{P}}(h)| \leq \sqrt{\frac{\log(2|\mathcal{H}|/\delta)}{2n}}. \tag{5.7}$$

由于该样本量不依赖 $\mathcal{P}$，有限假设空间满足分布无关的一致收敛。

**证明**　对每个 $h$ 使用式 (5.4)。上确界超过 $\eta$ 等价于至少一个候选的偏差超过 $\eta$；对这些事件求并集界，得到

$$\mathbb{P}\left(\sup_{h\in\mathcal{H}} |\hat{R}_S(h) - R_{\mathcal{P}}(h)| > \eta\right) \leq 2|\mathcal{H}|e^{-2n\eta^2}.$$

按式 (5.6)选择 $n$ 使右侧至多为 $\delta$；或令右侧等于 $\delta$，反解偏差 $\eta$，得到式 (5.7)。两种写法的样本要求均与具体 $\mathcal{P}$ 无关。 ■

在共同准确事件上，ERM 的训练比较可以变成总体比较。其输出 $\hat{h}$ 的经验风险不高于任意 $h \in \mathcal{H}$，再分别用两者的偏差界替换经验风险，即得到对总体超额风险的控制。下面据此计算有限空间的充分样本量。

**定理 5.3 有限假设空间的不可知 PAC 样本量界** 设 $(X, \mathcal{X})$ 为可测空间，$Y = \{0,1\}$ 取离散 $\sigma$ 代数，$\mathcal{H} \subseteq Y^X$ 是由可测分类器组成的非空有限集合，$\mathcal{P}$ 是 $X \times Y$ 上的任意联合分布。对零一损失，记

$$R_{\mathcal{P}}(h) = \mathbb{P}_{(x,y)\sim\mathcal{P}}\{h(x) \neq y\}, \qquad \hat{R}_S(h) = \frac{1}{n}\sum_{i=1}^{n} \mathbb{I}\{h(x_i) \neq y_i\}.$$

设 $n \geq 1$、$S = ((x_i, y_i))_{i=1}^{n} \sim \mathcal{P}^n$，可测学习算法 $A$（允许内部随机性）以概率 1 输出 $\hat{h} = A(S) \in \arg\min_{h\in\mathcal{H}} \hat{R}_S(h)$。对任意 $\varepsilon, \delta \in (0,1)$，只要

$$n \geq \frac{2}{\varepsilon^2}\left(\log(2|\mathcal{H}|) + \log\frac{1}{\delta}\right), \tag{5.8}$$

就有

$$\mathbb{P}_{S,A}\left(R_{\mathcal{P}}(\hat{h}) \leq \inf_{h\in\mathcal{H}} R_{\mathcal{P}}(h) + \varepsilon\right) \geq 1 - \delta.$$

概率同时来自样本抽取和 $A$ 的内部随机性。

**证明** 在定理 5.2中将容限设为 $\eta = \varepsilon/2$。式 (5.8)使全部风险偏差不超过这个容限的概率至少为 $1-\delta$。固定满足条件的样本，再取任意 $h \in \mathcal{H}$；输出 $\hat{h}$ 也在该空间内，两者均受偏差界约束。结合 ERM 的经验最优性，有

$$\begin{aligned} R_{\mathcal{P}}(\hat{h}) &\leq \hat{R}_S(\hat{h}) + \frac{\varepsilon}{2} \\ &\leq \hat{R}_S(h) + \frac{\varepsilon}{2} \\ &\leq R_{\mathcal{P}}(h) + \varepsilon. \end{aligned}$$

首尾两次比较分别连接输出和参照的经验风险与总体风险，中间一次使用 ERM。结论对任意 $h$ 成立，取下确界即得所需保证。 ■

这里控制输出比类内最低风险高多少。式 (5.3)的精度依赖是 $1/\varepsilon$，因为只须排除高风险者全分对；不可知分析要比较可能均有错误的候选，须估准各自的错误比例。式 (5.4)中的偏差概率按 $n\eta^2$ 指数下降，两次偏差比较于是给出 $1/\varepsilon^2$ 的充分界。这个差别来自评价事件的改变，不能从 PAC 名称推断。

同一偏差界也能落实定理 4.10的惩罚。设候选空间 $\mathcal{H}_1 \subseteq \mathcal{H}_2 \subseteq \cdots$ 预先给定且各有限。SRM 会看样本选序号 $k$ 及 $h \in \mathcal{H}_k$，仅保证某个预定空间准确还不够：它可能转而选中另一空间的偶然低经验风险。因此需要同时控制每个空间的全部候选。

在抽样前分配 $\delta_k > 0$，使 $\sum_k \delta_k \le \delta$，并对第 $k$ 个空间设置偏差上界

$$p_k = \sqrt{\frac{\log(2|\mathcal{H}_k|/\delta_k)}{2n}}.$$

式 (5.7)将第 $k$ 个空间内的失败概率控制为 $\delta_k$。再跨空间使用并集界，就以至少 $1-\delta$ 的概率在同一份样本上得到

$$|\hat{R}_S(h) - R_{\mathcal{P}}(h)| \le p_k \qquad (k \ge 1,\ h \in \mathcal{H}_k).$$

这个共同事件覆盖后来选择的任意 $(k,h)$，其期望风险都不超过经验风险加 $p_k$。因此结构风险最小化可选择以下目标最小的组合：

$$\hat{R}_S(h) + p_k \tag{5.9}$$

扩大 $\mathcal{H}_k$ 或缩小 $\delta_k$ 都会增大惩罚。一个具体分配为 $\delta_k = \delta/[k(k+1)]$；由 $1/[k(k+1)] = 1/k - 1/(k+1)$，总预算恰为 $\delta$。

失败预算还可以按空间的描述长度分配。给序号 $k$ 预定一个二进制编码，并要求任一编码都不是另一个的开头，得到前缀编码，例如 $0, 10, 11$ 标记三个空间。设编码长为 $L_k$。在足够长的二进制串中，以该编码开头者占 $2^{-L_k}$，不同前缀对应的串互不重叠，任意有限组的比例和便不超过 1。由此全部编码也满足 $\sum_k 2^{-L_k} \le 1$，可以取 $\delta_k = \delta 2^{-L_k}$。由于 $\log(1/\delta_k) = \log(1/\delta) + L_k \log 2$，较长空间描述带来较小预算与较大 $p_k$。这里编码只描述选哪个空间，作用是有效分配失败概率，并非 PAC 定义另加的必要条件。

## 5.3 无限假设空间

有限空间可逐候选加失败概率，得到式 (5.6)的样本量；无限空间这样求和则失去有限上界。我们改问：在一组有限输入上，这些函数能产生多少种不同预测？很多函数若在该组输入上回答相同，就无需在经验风险分析中分别计数。

### 5.3.1 VC 维与生长函数的学习论接口

为处理无限类，我们先统计它在有限输入上可出现的预测模式；后面的对称化会说明为何这项计数能够进入风险分析。**限制**（restriction）类 $\mathcal{H}|_C$ 保留函数在 $C$ 上的取值，**生长函数**（growth function）计算 $m$ 个输入上的最大模式数（可参考第一卷“计数与计算”章的生长函数定义）。在本章的学习记号下，这个计数为

$$\Pi_{\mathcal{H}}(m) = \max_{x_1,\dots,x_m \in X} \left|\{(h(x_1),\dots,h(x_m)) : h \in \mathcal{H}\}\right|. \tag{5.10}$$

它计算 $m$ 个输入上最多可出现多少种二元预测。允许输入重复，因而有限输入空间也能使用任意 $m$。阈值与单区间的 VC 维分别为 1 和 2，前者的生长函数为 $m+1$，后者为 $1+m(m+1)/2$（可参考第一卷“计数与计算”章的“二值函数族的容量”部分）。平面仿射半空间的 VC 维为 3。现在要将这些容量信息转为一致收敛和样本量保证，所需的组合上界如下。

### 5.3.2 Sauer–Shelah 引理

有限 VC 维把预测数限制在多项式量级。具体地，设 $\mathcal{H} \subseteq \{0,1\}^X$ 非空且 $1 \le d = \mathrm{VC}(\mathcal{H}) < \infty$，Sauer–Shelah 界对每个整数 $m \ge d$ 给出

$$\Pi_{\mathcal{H}}(m) \le \sum_{j=0}^{d} \binom{m}{j} \le \left(\frac{em}{d}\right)^{d} \tag{5.11}$$

（可参考第一卷“计数与计算”章的 Sauer–Shelah 引理）。这一界将无限函数类转为合并样本上的有限模式计数，下一小节再把它代入对称化后的失败概率。$d=0$ 时每个输入的预测唯一，生长函数恒为 1，应单独处理，避免使用以 $d$ 作分母的式子。

固定 $d$ 时，Sauer–Shelah 的界至多按 $m^d$ 增长，全部二元预测却有 $2^m$ 种。有限 VC 维因而阻止生长函数持续指数增长。它给的是上界，实际可以更慢；例如 VC 维 3 的平面仿射半空间只有 $m^2$ 量级的预测数。

用同一对数坐标比较 $2^m$ 与单区间类的精确模式数 $1+m(m+1)/2$，可以看到全部二元组合与有限 VC 类的增长差别（可参考第一卷“计数与计算”章的“二值函数族的容量”部分中的模式数图）。两者差距随 $m$ 扩大，可实现模式占全部组合的比例变小，候选函数本身仍可以无限。

### 5.3.3 二分类可学习性基本定理

一致收敛已说明怎样把 ERM 的训练比较转成总体比较。现在候选无限，所需的是所有风险差的共同概率控制。生长函数只数有限输入上的预测，接下来用第二份样本把未知总体风险换成有限输入上的可比较量。

在证明中独立抽取副样本 $S' = (z'_1, \dots, z'_n)$，与 $S = (z_1, \dots, z_n)$ 同来自联合分布 $\mathcal{P}$，$z_i = (x_i, y_i)$。这份**副样本**（ghost sample）使未知风险能够通过另一份经验平均分析，学习算法不需要实际得到它。

固定 $S$ 选定 $h$ 后，$S'$ 未参与选解，因此 $\hat{R}_{S'}(h)$ 对其独立评价，平均值就是 $R_{\mathcal{P}}(h)$。若原经验风险偏离总体很大、副样本风险又接近总体，两份经验风险必有较大差异。我们因此以双样本差事件控制原样本偏差事件。此步骤只对原样本选出的那个假设使用副样本估计，尚不要求副样本同时估准全部候选。

双样本只涉及 $2n$ 个输入，同预测的函数给出相同经验风险，故至多需要区分 $\Pi_{\mathcal{H}}(2n)$ 种结果。再让每对 $(z_i, z_i')$ 独立公平交换或保持原位。iid 使联合分布不变，固定预测的差贡献则随机变号，可以应用集中不等式。将各预测的尾概率相加，就控制了任意候选产生大差的概率。副样本与随机交换构成**对称化**（symmetrization），作用是把总体比较转成有限计数及随机符号比较。

下面依次使用副样本、交换与预测计数，得到同时偏差的概率界。

**定理 5.4　VC 一致收敛界**　设 $(X, \mathcal{X})$ 为可测空间，$Y = \{0, 1\}$ 取离散 $\sigma$ 代数，$\mathcal{H} \subseteq Y^X$ 是由可测分类器组成的非空集合，零一损失函数类

$$\mathcal{F}_{\mathcal{H}} = \{(x, y) \mapsto \mathbb{I}\{h(x) \neq y\} : h \in \mathcal{H}\}$$

中的每个函数均可测，并存在可数子类 $\mathcal{F}_0 \subseteq \mathcal{F}_{\mathcal{H}}$，使 $\mathcal{F}_{\mathcal{H}}$ 中的每个函数都是 $\mathcal{F}_0$ 中某个函数序列的逐点极限。设 $\mathcal{P}$ 是 $X \times Y$ 上的任意联合分布，$n \geq 1$，$S = ((x_i, y_i))_{i=1}^n \sim \mathcal{P}^n$，并记

$$R_{\mathcal{P}}(h) = \mathbb{P}_{(x,y)\sim\mathcal{P}}\{h(x) \neq y\}, \qquad \hat{R}_S(h) = \frac{1}{n}\sum_{i=1}^{n} \mathbb{I}\{h(x_i) \neq y_i\},$$

$$\Pi_{\mathcal{H}}(m) = \max_{x_1,\dots,x_m \in X} \left|\{(h(x_1), \dots, h(x_m)) : h \in \mathcal{H}\}\right|.$$

令 $d = \mathrm{VC}(\mathcal{H})$。对任意 $\eta > 0$，只要 $n\eta^2 \geq 2$，就有

$$\mathbb{P}_{S\sim\mathcal{P}^n}\left\{\sup_{h\in\mathcal{H}} |R_{\mathcal{P}}(h) - \hat{R}_S(h)| > \eta\right\} \leq 4\Pi_{\mathcal{H}}(2n) e^{-n\eta^2/8}. \tag{5.12}$$

因而对任意 $\delta \in (0, 1)$，当 $1 \leq d \leq 2n$ 时，以至少 $1 - \delta$ 的概率，

$$\sup_{h\in\mathcal{H}} |R_{\mathcal{P}}(h) - \hat{R}_S(h)| \leq \sqrt{\frac{8}{n}\left[d \log \frac{2en}{d} + \log \frac{4}{\delta}\right]}. \tag{5.13}$$

若右侧大于 1，则可用零一损失给出的平凡上界 1 替代。

**证明**　引入独立副样本 $S' \sim \mathcal{P}^n$。固定已发生原偏差事件的 $S$，选 $h$ 使 $|R_{\mathcal{P}}(h) - \hat{R}_S(h)| > \eta$。条件于 $S$ 及 $h$ 后，副样本经验风险仍为 $n$ 个独立 Bernoulli 损失的平均，故

$$\mathrm{Var}_{S'}\big(\hat{R}_{S'}(h) \mid S\big) \leq \frac{1}{4n}.$$

用 Chebyshev 不等式控制它相对真实风险的偏差：

$$\mathbb{P}_{S'}\left(|\hat{R}_{S'}(h)-R_{\mathcal{P}}(h)|\geq\frac{\eta}{2}\,\middle|\,S\right)\leq\frac{1}{n\eta^2}\leq\frac{1}{2}.$$

以至少 $1/2$ 的条件概率，副样本偏差小于 $\eta/2$，这时三角不等式使两份经验风险相差大于 $\eta/2$。对原样本平均后得到

$$\mathbb{P}\left\{\sup_{h}|R_{\mathcal{P}}(h)-\hat{R}_S(h)|>\eta\right\}\leq 2\mathbb{P}\left\{\sup_{h}|\hat{R}_{S'}(h)-\hat{R}_S(h)|>\frac{\eta}{2}\right\}.$$

固定两份样本的 $2n$ 个观测，记配对为 $(z_i,z_i')$。引入独立 Rademacher 符号，$\sigma_i=1$ 时保持该对，$\sigma_i=-1$ 时交换，形成 $S_\sigma,S'_\sigma$。原样本独立同分布，随机交换保持联合分布；固定观测与 $h$ 后的差值则为

$$\hat{R}_{S'_\sigma}(h)-\hat{R}_{S_\sigma}(h)=\frac{1}{n}\sum_{i=1}^{n}\sigma_i\left[\ell_{01}(h(x_i'),y_i')-\ell_{01}(h(x_i),y_i)\right].$$

各项的取值区间长度至多 $2/n$，Hoeffding 给出尾界 $2e^{-n\eta^2/8}$。固定输入上的预测向量至多 $\Pi_{\mathcal{H}}(2n)$ 种，固定标签后每个预测向量确定一个损失向量。只对这些有限向量作并集界，得到

$$\mathbb{P}_{\sigma}\left\{\sup_{h}|\hat{R}_{S'_\sigma}(h)-\hat{R}_{S_\sigma}(h)|>\frac{\eta}{2}\,\middle|\,S,S'\right\}\leq 2\Pi_{\mathcal{H}}(2n)e^{-n\eta^2/8}.$$

先平均固定观测，再利用交换不改变联合分布，将这一界转回双样本差；乘上对称化的因子 2，得到式 (5.12)。代入 Sauer–Shelah 上界 $\Pi_{\mathcal{H}}(2n)\leq(2en/d)^d$ 并解出失败概率 $\delta$ 对应的偏差，即得式 (5.13)。 ■

固定有限 $d$ 及 $\delta$，式 (5.13)随 $n$ 趋于零。因此任意偏差容限都能用充分样本量达到，成功概率至少 $1-\delta$，且同一阈值适用于全部相关联合分布。这正是分布无关一致收敛。

一致收敛经 ERM 比较给不可知 PAC；无限 VC 维则由没有免费的午餐排除可实现 PAC。有限维度、两类学习与一致收敛于是形成等价关系。式 (5.13)足以建立等价性，其中对数项却未必是最优样本复杂度所必需的。

**定理 5.5　二分类学习基本定理**　设 $(X,\mathcal{X})$ 为可测空间，$Y=\{0,1\}$ 取离散 $\sigma$ 代数，$\mathcal{H}\subseteq Y^X$ 是由可测分类器组成的非空假设空间，并采用零一损失。假定损失类

$$\mathcal{F}_{\mathcal{H}}=\{(x,y)\mapsto\mathbb{I}\{h(x)\neq y\}:h\in\mathcal{H}\}$$

中的每个函数均可测，且存在可数子类 $\mathcal{F}_0 \subseteq \mathcal{F}_{\mathcal{H}}$，使 $\mathcal{F}_{\mathcal{H}}$ 中的每个函数都是 $\mathcal{F}_0$ 中某个函数序列的逐点极限。所有分布均指 $X \times Y$ 上的联合分布，训练样本均为 $S \sim \mathcal{P}^n$；学习算法是可测映射并输出 $\mathcal{H}$ 中的分类器，成功概率同时计入样本抽取和算法的内部随机性。在这一分布无关设定中，下列命题等价：

1. $\mathcal{H}$ 是不可知 PAC 可学习的；
2. $\mathcal{H}$ 是可实现 PAC 可学习的；
3. $\mathcal{H}$ 满足一致收敛；
4. $\mathrm{VC}(\mathcal{H}) < \infty$。

**证明**　VC 维为 0 时，各输入处预测唯一，固定假设的集中界便给出一致收敛。VC 维为正且有限时，先经 Sauer–Shelah 限制合并样本的预测数，再由对称化得到式 (5.13)，所以推出一致收敛。固定一致收敛成功事件，ERM 的经验风险不超过任意参照；将输出和参照各用一个 $\eta$ 连接到总体风险，得超额风险至多 $2\eta$。取 $\eta = \varepsilon/2$ 便得到不可知 PAC；它覆盖可实现来源，也给出可实现 PAC。

若 VC 维无限，任意 $n$ 都能找到被打散的 $2n$ 个输入。对任意算法，第 4.3.2节的定理在这些输入上给出一个可实现分布，使 $n$ 个观测下的风险以固定正概率超过固定误差阈值。任意样本量都存在这样的分布，违反可实现 PAC 的统一要求，故可实现 PAC 可学习必有有限 VC 维。结合正向蕴含，四个命题等价。 ■

定理把第 4章的 PAC 量词落实为容量条件，判断是否存在统一学习保证。要使样本量与下界匹配，还须比定性可学习性更精细的分析。

**定理 5.6　二分类的最优样本复杂度阶**　存在普适常数 $c_0 \in (0, 1/2)$，使以下结论成立。设 $(X, \mathcal{X})$ 为可测空间，$Y = \{0, 1\}$ 取离散 $\sigma$ 代数，$\mathcal{H} \subseteq Y^X$ 是由可测分类器组成的非空假设空间，$2 \le d = \mathrm{VC}(\mathcal{H}) < \infty$。假定零一损失类中的函数均可测，并存在可数损失子类，使每个损失函数都是该子类中某个函数序列的逐点极限。对所有 $\varepsilon, \delta \in (0, c_0]$，令训练样本 $S \sim \mathcal{P}^n$，其中 $\mathcal{P}$ 遍历 $X \times Y$ 上的联合分布，成功概率同时计入样本抽取和学习算法的内部随机性。在允许算法输出任意可

测二分类器的分布无关极小极大意义下，可实现 PAC 学习的最优样本复杂度阶为

$$\Theta\left(\frac{d+\log(1/\delta)}{\varepsilon}\right),$$

不可知 PAC 学习的最优样本复杂度阶为

$$\Theta\left(\frac{d+\log(1/\delta)}{\varepsilon^2}\right).$$

这里的 $\Theta$ 上下界常数均为与 $\mathcal{H},\varepsilon,\delta$ 无关的普适常数。

匹配的最优阶需要上下界，不能单靠定理 5.4获得。经典可实现 ERM 分析有额外 $\log(1/\varepsilon)$，精细的非恰当学习器可去掉它[1,2]。任意 ERM 或恰当输出不因此都达到相同阶，$d=0,1$ 也须另处理。统计最优仍未给出易算程序，计算条件留待章末。

## 5.4 估计期望风险

VC 维回答了二分类是否能统一学习。对于样本已经选出的一个假设，我们还想知道它的总体风险上限。经验损失可直接计算，未知来源上的损失则需要在经验值之外补一个偏差控制量。

VC 界按全输入空间的打散能力控制偏差，尚未利用当前样本位置和函数值。Rademacher 与高斯复杂度保留这些信息，给出“经验风险加复杂度及抽样误差”的高概率上界。这里估计的是风险上限，没有宣称有限样本能够精确恢复未知总体风险。

### 5.4.1 Rademacher 复杂度

本章先控制经验均值低估总体均值的方向，使用不带绝对值的单侧随机复杂度：先在类中取最大的随机相关和，再对独立符号平均（可参考第一卷“随机变量”章的经验 Rademacher 复杂度定义）。对 $S=(z_1,\dots,z_n)$ 与非空实值类 $\mathcal{G}$，在学习场景中记为

$$\widehat{\mathfrak{R}}_S(\mathcal{G})=\mathbb{E}_\sigma\left[\sup_{f\in\mathcal{G}}\frac{1}{n}\sum_{i=1}^{n}\sigma_i f(z_i)\right]. \tag{5.14}$$

符号 $\sigma_i$ 独立且等概率取 $-1,1$，再对样本平均得到

$$\mathfrak{R}_n(\mathcal{G})=\mathbb{E}_{S\sim\mathcal{P}^n}\widehat{\mathfrak{R}}_S(\mathcal{G}).$$

带绝对值的版本等于 $\mathcal{G}\cup(-\mathcal{G})$ 的单侧复杂度；在取负封闭的类上两者相同，一般则绝对值版本不小于单侧版本（可参考第一卷“随机变量”章的

“候选族累计量的统一偏差控制”一节）。使用收缩或比较结果时须按版本核对常数。

### 5.4.2　线性预测的复杂度

对线性得分 $f_{\boldsymbol{w}}(\boldsymbol{x})=\boldsymbol{w}^{\top}\boldsymbol{x}$，随机相关和可写成 $\boldsymbol{w}^{\top}\sum_i \sigma_i \boldsymbol{x}_i$。若参数不受限且后一个向量非零，这个量可任意增大，复杂度便不能给出有限控制。为此设 $B>0$ 并限制 $\|\boldsymbol{w}\|_2\le B$，取 $\mathcal{F}=\{\boldsymbol{x}\mapsto \boldsymbol{w}^{\top}\boldsymbol{x}:\|\boldsymbol{w}\|_2\le B\}$，假定每个样本输入满足 $\|\boldsymbol{x}_i\|_2\le r$。以 $S_X=(\boldsymbol{x}_1,\dots,\boldsymbol{x}_n)$ 记输入样本，先计算得分复杂度：

$$\begin{aligned}\widehat{\mathfrak{R}}_{S_X}(\mathcal{F}) &= \frac{1}{n}\mathbb{E}_{\sigma}\sup_{\|\boldsymbol{w}\|_2\le B}\boldsymbol{w}^{\top}\sum_{i}\sigma_i\boldsymbol{x}_i \\ &\le \frac{B}{n}\sqrt{\sum_{i}\|\boldsymbol{x}_i\|_2^2}\le\frac{Br}{\sqrt{n}}.\end{aligned}\tag{5.15}$$

固定符号时，参数沿 $\sum_i \sigma_i\boldsymbol{x}_i$ 方向取长度 $B$ 即可达到最大内积。用均方范数的平方根上界期望范数，独立符号又使交叉项的期望为零，剩下 $\sum_i\|\boldsymbol{x}_i\|_2^2$。上界虽未显式含维数，却依赖 $B$ 和 $r$ 受控；缺少半径约束时，不能宣称维数无关。

### 5.4.3　由 Rademacher 复杂度估计期望风险

预测得分的复杂度还须转为损失的复杂度，才能评价风险。设 $\ell\in[0,1]$，对 $z=(x,y)$ 定义 $g_h(z)=\ell(h(x),y)$，组成 $\mathcal{G}=\{g_h:h\in\mathcal{H}\}$。样本均值为 $\hat{R}_S(h)$，总体均值为 $R_{\mathcal{P}}(h)$；控制两者之差，就能由训练值上界总体风险。

**定理 5.7　Rademacher 复杂度给出的期望风险上界**　设 $(Z,\mathcal{A})$ 为可测空间，$\mathcal{P}$ 为 $Z$ 上的概率分布，$n\ge 1$，$S=(z_1,\dots,z_n)\sim\mathcal{P}^n$。令 $\mathcal{G}$ 为抽样前确定的、从 $Z$ 到 $[0,1]$ 的非空可测函数空间；假定存在可数子类 $\mathcal{G}_0\subseteq\mathcal{G}$，使 $\mathcal{G}$ 中的每个函数都是 $\mathcal{G}_0$ 中某个函数序列的逐点极限。对独立于 $S$ 且相互独立、等概率取 $-1,1$ 的随机变量 $\sigma_1,\dots,\sigma_n$，定义

$$\widehat{\mathfrak{R}}_S(\mathcal{G})=\mathbb{E}_{\sigma}\left[\sup_{g\in\mathcal{G}}\frac{1}{n}\sum_{i=1}^{n}\sigma_i g(z_i)\right],\qquad \mathfrak{R}_n(\mathcal{G})=\mathbb{E}_{S\sim\mathcal{P}^n}\widehat{\mathfrak{R}}_S(\mathcal{G}).$$

则对任意 $\delta\in(0,1)$，以关于 $S\sim\mathcal{P}^n$ 至少 $1-\delta$ 的概率，对所有 $g\in\mathcal{G}$ 同时有

$$\mathbb{E}_{z\sim\mathcal{P}}g(z)\le\frac{1}{n}\sum_{i}g(z_i)+2\mathfrak{R}_n(\mathcal{G})+\sqrt{\frac{\log(1/\delta)}{2n}}.\tag{5.16}$$

另有一个由样本确定的上界：以关于 $S \sim \mathcal{P}^n$ 至少 $1-\delta$ 的概率，对所有 $g \in \mathcal{G}$ 同时有

$$\mathbb{E}_{z\sim\mathcal{P}} g(z) \le \frac{1}{n}\sum_{i} g(z_i) + 2\widehat{\mathfrak{R}}_S(\mathcal{G}) + 3\sqrt{\frac{\log(2/\delta)}{2n}}. \tag{5.17}$$

**证明**　令 $\Phi(S) = \sup_{g\in\mathcal{G}} (\mathbb{E}g - n^{-1}\sum_i g(z_i))$，即经验均值在整个类上的最大低估。引入独立副样本，用“先选择函数再平均”上界“先平均再选择”，得

$$\mathbb{E}_S \Phi(S) \le \mathbb{E}_{S,S'} \sup_{g\in\mathcal{G}} \frac{1}{n}\sum_{i} \bigl(g(z_i') - g(z_i)\bigr).$$

对每对观测随机交换，将独立符号 $\sigma_i$ 引入差值而不改变期望。把两样本和各自取上确界，再用 $\sigma_i$ 与 $-\sigma_i$ 同分布，得到

$$\mathbb{E}_S \Phi(S) \le 2\mathfrak{R}_n(\mathcal{G}). \tag{5.18}$$

替换一个观测使 $\Phi(S)$ 最多变化 $1/n$。有界差分不等式使它以至少 $1-\delta$ 的概率不超过期望加 $\sqrt{\log(1/\delta)/(2n)}$，结合上式证明第一界。经验 Rademacher 复杂度替换一个观测也至多变化 $1/n$，所以以至少 $1-\delta/2$ 的概率，

$$\mathfrak{R}_n(\mathcal{G}) \le \widehat{\mathfrak{R}}_S(\mathcal{G}) + \sqrt{\frac{\log(2/\delta)}{2n}}.$$

再把第一界的失败预算设为 $\delta/2$，两个事件的共同概率至少 $1-\delta$。替换其中的期望复杂度并合并三项偏差，得到第二界。 ■

取 $g = g_h$ 后，左侧是总体风险，右侧首项是经验风险，另外两项补偿由样本均值推断总体均值的复杂度与抽样代价。共同保证覆盖全部 $h$，所以也覆盖数据选解。经验版本可按当前样本估复杂度，同 VC 维空间也可能因样本函数值不同得到不同风险界，这正是数据相关分析的用途[3]。

得分与零一损失不是同一个函数。若损失对得分为 $L$-Lipschitz，得分改变 $a$ 时，损失至多改变 $L|a|$，**收缩引理**（contraction lemma）便能将预测复杂度转成损失复杂度。本章的单侧版本使用系数 $L$；$\phi(0) \neq 0$ 时先减该常数，随机和的期望不变。一般绝对值版本还可能多出因子 2，不能混用两种口径（可参考第一卷“随机变量”章的“候选族累计量的统一偏差控制”一节）。只有核对这种变化率条件之后才能转界，式 (5.15)本身不是零一风险界。

将得分复杂度转为分类风险，还要选择损失。取 $y \in \{-1, 1\}$、$f(\boldsymbol{x}) = \boldsymbol{w}^{\top}\boldsymbol{x}$，则 $yf(\boldsymbol{x})$ 为带符号的分类间隔：正值表示方向正确，绝对大小在得分尺度上衡量距阈值 0 的距离。参数向量非零时，几何间隔还须除以 $\|\boldsymbol{w}\|_2$。对固定 $\rho > 0$，用下列间隔损失同时惩罚错分和不足的正间隔：

$$\ell_{\rho}(f(\boldsymbol{x}), y) = \begin{cases} 1, & yf(\boldsymbol{x}) \le 0, \\ 1 - yf(\boldsymbol{x})/\rho, & 0 < yf(\boldsymbol{x}) < \rho, \\ 0, & yf(\boldsymbol{x}) \ge \rho. \end{cases}$$

它在错分时为 1，在正确但间隔小于 $\rho$ 时仍为正，取值于 $[0, 1]$、关于得分为 $1/\rho$-Lipschitz，且支配零一损失。若 $\|\boldsymbol{w}\|_2 \le B$、$\|\boldsymbol{x}\|_2 \le r$ 几乎处处成立，收缩引理将式 (5.15)转为损失复杂度 $Br/(\rho\sqrt{n})$。风险上界因而以至少 $1 - \delta$ 的概率同时覆盖所有这些线性得分：

$$R_{\mathcal{P}}^{01}(\operatorname{sign} f) \le \frac{1}{n}\sum_{i} \ell_{\rho}(f(\boldsymbol{x}_i), y_i) + \frac{2Br}{\rho\sqrt{n}} + \sqrt{\frac{\log(1/\delta)}{2n}}. \tag{5.19}$$

这里 $R_{\mathcal{P}}^{01}$ 采用零一损失，得分为 0 时的分类规则预先固定。若经验间隔损失为零，使右侧至多为 $\varepsilon$ 的一项充分样本量为 $O(((Br/\rho)^2 + \log(1/\delta))/\varepsilon^2)$。控制量是范数与间隔的比值；高维而间隔较大时，它可能优于仅依据半空间 VC 维的保证。

范数、输入界和小间隔损失是这条保证额外利用的条件，并未改变二分类基本定理。只缩小参数而不改分类符号，得分间隔也相应缩小，风险界不能据此保证改善。数据相关复杂度可利用具体值并推广实值损失，却未承诺总比 VC 样本界小，也未使无限 VC 二类空间在全部分布上可学习。

ERM 还要比较输出与参照的两个风险，故需双侧偏差。将第一界分别应用于 $\mathcal{G}$ 和 $1 - \mathcal{G} = \{1 - g : g \in \mathcal{G}\}$，两者均取值于 $[0, 1]$。平移不改变总体与经验均值之差，符号对称性又给出 $\mathfrak{R}_n(1 - \mathcal{G}) = \mathfrak{R}_n(\mathcal{G})$。各分配 $\delta/2$ 后，以至少 $1 - \delta$ 的概率有

$$|R_{\mathcal{P}}(h) - \hat{R}_S(h)| \le 2\mathfrak{R}_n(\mathcal{G}) + \sqrt{\frac{\log(2/\delta)}{2n}}.$$

沿用两次偏差比较，ERM 的超额风险因此满足

$$R_{\mathcal{P}}(\hat{h}) - \inf_{h \in \mathcal{H}} R_{\mathcal{P}}(h) \le 4\mathfrak{R}_n(\mathcal{G}) + 2\sqrt{\frac{\log(2/\delta)}{2n}}. \tag{5.20}$$

对固定分布，$\mathfrak{R}_n(\mathcal{G}) \to 0$ 使输出风险以高概率趋近类内下确界。若有对全部允许分布成立的统一上界 $\mathfrak{R}_n(\mathcal{G}) \le a_n \to 0$，才可从中选择分布无关的样本量，得到不可知 PAC。单个分布上的小复杂度不等于这一统一保证。

### 5.4.4 高斯复杂度

把等幅随机符号换成标准高斯系数，可以从另一种随机相关和估计损失类复杂度。两种系数的幅度规律不同，需要先核对比较方向（可参考第一卷“随机变量”章的高斯复杂度定义及同章的“候选族累计量的统一偏差控制”一节）。对独立标准高斯系数 $\xi_i$，本章使用单侧**经验高斯复杂度**（empirical Gaussian complexity）

$$\widehat{\mathfrak{G}}_S(\mathcal{G}) = \mathbb{E}_\xi\left[\sup_{g\in\mathcal{G}} \frac{1}{n}\sum_{i} \xi_i g(z_i)\right].$$

高斯幅度可变，而 Rademacher 幅度恒为 1，二者一般不能双向由普适常数比较。将 $\xi_i$ 写成 $\sigma_i|\xi_i|$，由上确界的凸性得到 $\widehat{\mathfrak{G}}_S(\mathcal{G}) \geq \sqrt{2/\pi}\,\widehat{\mathfrak{R}}_S(\mathcal{G})$。若已有高斯上界 $b(S)$，便得 Rademacher 上界 $\sqrt{\pi/2}\,b(S)$，可代入式 (5.17)。

将这种比较代入经验风险式，就得到以高斯复杂度表示的总体风险上界。

**定理 5.8　高斯复杂度给出的期望风险上界**　设 $(Z,\mathcal{A})$ 为可测空间，$\mathcal{P}$ 为 $Z$ 上的概率分布，$n\geq 1$，$S=(z_1,\dots,z_n)\sim\mathcal{P}^n$。令 $\mathcal{G}=\{g_h : h\in\mathcal{H}\}$ 为抽样前确定的、从 $Z$ 到 $[0,1]$ 的非空可测损失函数空间，并存在可数子类 $\mathcal{G}_0\subseteq\mathcal{G}$，使 $\mathcal{G}$ 中的每个函数都是 $\mathcal{G}_0$ 中某个函数序列的逐点极限。定义

$$R_{\mathcal{P}}(h)=\mathbb{E}_{z\sim\mathcal{P}} g_h(z), \qquad \hat{R}_S(h)=\frac{1}{n}\sum_{i=1}^{n} g_h(z_i),$$

并对独立于 $S$ 的独立标准高斯变量 $\xi_1,\dots,\xi_n$ 定义

$$\widehat{\mathfrak{G}}_S(\mathcal{G}) = \mathbb{E}_\xi\left[\sup_{g\in\mathcal{G}} \frac{1}{n}\sum_{i=1}^{n} \xi_i g(z_i)\right].$$

则对任意 $\delta\in(0,1)$，以关于 $S\sim\mathcal{P}^n$ 至少 $1-\delta$ 的概率，所有 $h\in\mathcal{H}$ 同时满足

$$R_{\mathcal{P}}(h) \leq \hat{R}_S(h) + \sqrt{2\pi}\,\widehat{\mathfrak{G}}_S(\mathcal{G}) + 3\sqrt{\frac{\log(2/\delta)}{2n}}. \tag{5.21}$$

**证明**　将 $g=g_h$ 代入式 (5.17)，再用 $2\widehat{\mathfrak{R}}_S(\mathcal{G})\leq\sqrt{2\pi}\,\widehat{\mathfrak{G}}_S(\mathcal{G})$ 替换复杂度项，即得结论。 ■

使用时计算输出的经验风险，再为损失类的经验高斯复杂度求上界，代入式 (5.21)。已知 $b(S)$ 时可直接替换复杂度项。由于事件同时覆盖全部候选，输出即使在看过样本后选择也适用。

高斯量给出估计复杂度的另一途径，未必使风险界更小，反向比较还可能付出随 $n$ 增长的因子。限制向量只有 $\{\pm \boldsymbol{e}_i : 1 \le i \le n\}$ 时，两量分别为 $1/n$ 与 $\mathbb{E}\max_i |\xi_i|/n$。因此替换公式时须核对所需的比较方向及因子。

## 5.5 样本压缩

容量与随机复杂度控制候选类，另一条路线限制输出需要的样本信息。如果保留少量带标签记录便能重构一个分对全部样本的假设，我们就可以用这个描述约束泛化。**样本压缩**（sample compression）研究这种重构。保留观测数与旁信息长度若对全部可实现样本统一有界，还能支持可学习性。

### 5.5.1 从样本到假设的重构

取递增阈值 $h_t(x) = \mathbb{I}\{x \ge t\}$，样本分数 0.1、0.3、0.7、0.9 的标签为 0、0、1、1。只保留最小正例 $(0.7, 1)$，约定它的输入作阈值，就重构 $h_{0.7}$ 并分对四个输入。要求是保留训练一致性，没有要求恢复总体真实阈值。

任意可由递增阈值实现的有限样本都可这样处理：保留最小正例，所有负例在其左，其他正例在其右或与它重合。无正例时保留空样本，约定重构全 0 函数。全 0 可能不在实数阈值空间，本节因此允许非恰当重构。

方案需要预先固定压缩与重构两映射。前者读完整样本选记录，后者只读这些记录输出假设。若还保留有限二进制串来指定重构方式，称为**旁信息**（side information）；其长度也须计费，不能用它无界保存原数据。

**定义 5.9　一致样本压缩方案**　设 $\mathcal{H} \subseteq \{0,1\}^X$，$k, b$ 为非负整数。一个 $(k, b)$ 一致样本压缩方案由固定的确定性映射 $\kappa$ 和 $\rho$ 组成。对任意有限样本 $S = ((x_i, y_i))_{i=1}^{n}$，若存在 $h \in \mathcal{H}$ 使 $h(x_i) = y_i$ 对所有 $i$ 成立，则 $\kappa(S) = (S_I, u)$ 满足

$$I \subseteq \{1, \dots, n\}, \qquad |I| \le k, \qquad u \in \{0,1\}^b,$$

其中 $S_I$ 按原样本中的次序排列。重构映射仅以 $(S_I, u)$ 为输入，输出 $\rho(S_I, u) : X \to \{0,1\}$，且满足

$$\rho(S_I, u)(x_i) = y_i, \qquad i = 1, \dots, n.$$

同一对映射须对每份可实现样本有效，$k, b$ 不随样本量增长，重构也不能读未保留观测或未经计费的位置编号。阈值方案为 $k = 1, b = 0$，一个

正例与空样本已能区分两种规则。本章把总规模记为 $s = k + b$，每记录与每比特各计一单位；风险公式仍分开计 $k, b$，因为它们分别改变剩余检验数与重构方式数。

### 5.5.2 期望风险与可学习性保证

一致性尚未保证低总体风险，关键是重构描述数受 $(k, b)$ 限制。样本中保留 $j$ 个位置有 $\binom{n}{j}$ 种选择，旁信息最多 $2^b$ 种，故需要合并的描述总数至多 $2^b \sum_{j=0}^{k} \binom{n}{j}$。

固定一种保留位置与旁信息后，假设只依赖保留观测，未保留者仍独立检验它。高风险假设全分对这些检验数据的概率很小。实际压缩按完整数据选描述，但对全部可能描述加失败概率，即可控制最终选择。

**定理 5.10　一致样本压缩的期望风险上界**　设 $(X, \mathcal{X})$ 为可测空间，$Y = \{0, 1\}$ 取离散 $\sigma$ 代数，$\mathcal{H} \subseteq Y^X$ 是由可测分类器组成的非空集合，$k, b$ 为非负整数。设可测确定性压缩映射 $\kappa$ 和重构映射 $\rho$ 满足：对每份可由 $\mathcal{H}$ 正确分类的有限样本 $S = ((x_i, y_i))_{i=1}^{n}$，有 $\kappa(S) = (S_I, u)$，其中 $I \subseteq \{1, \dots, n\}$、$|I| \le k$、$u \in \{0,1\}^b$；$\rho$ 只读取 $(S_I, u)$ 并输出 $h_S = \rho(S_I, u) : X \to Y$，且 $h_S(x_i) = y_i$ 对所有 $i$ 成立。假定对 $\rho$ 可能输出的每个 $h$，函数 $(x, y) \mapsto \mathbb{I}\{h(x) \neq y\}$ 均可测。令 $\mathcal{P}$ 为 $X \times Y$ 上的联合分布，存在 $h^\star \in \mathcal{H}$ 满足 $\mathbb{P}_{(x,y)\sim\mathcal{P}}\{h^\star(x) \neq y\} = 0$。若 $n > k$ 且 $S \sim \mathcal{P}^n$，则对任意 $\delta \in (0, 1)$，以至少 $1 - \delta$ 的概率，重构假设 $h_S = \rho(\kappa(S))$ 的零一损失期望风险 $R_{\mathcal{P}}(h_S) = \mathbb{P}_{(x,y)\sim\mathcal{P}}\{h_S(x) \neq y\}$ 满足

$$R_{\mathcal{P}}(h_S) \le \frac{b \log 2 + \log\left(\sum_{j=0}^{k} \binom{n}{j}\right) + \log(1/\delta)}{n - k}. \tag{5.22}$$

概率仅来自独立同分布样本 $S \sim \mathcal{P}^n$。

**证明**　先固定一种描述 $(I, u)$，其中 $|I| = j \le k$，而不条件于压缩算法选中它。给定 $S_I$，重构 $h_{I,u} = \rho(S_I, u)$ 已确定，余下 $n - j$ 个观测仍独立服从 $\mathcal{P}$。若其风险超过 $\varepsilon$，这些观测全被分对的条件概率至多为

$$(1 - \varepsilon)^{n-j} \le e^{-(n-j)\varepsilon} \le e^{-(n-k)\varepsilon}.$$

再平均 $S_I$，可知该固定描述同时导致高风险和全样本一致的概率至多 $e^{-(n-k)\varepsilon}$。

最终输出总由某个 $(I,u)$ 重构，并与全样本一致。输出风险超过 $\varepsilon$ 时，至少一种描述满足前述失败事件；对全部描述作并集界得到

$$\mathbb{P}\{R_{\mathcal{P}}(h_S)>\varepsilon\}\le 2^{b}\left(\sum_{j=0}^{k}\binom{n}{j}\right)e^{-(n-k)\varepsilon}.$$

令右侧至多为 $\delta$，取对数并整理即得式 (5.22)。若所列上界不小于 1，零一风险本身至多为 1 已保证结论。 ■

描述长度通过保留位置数与旁信息数进入分子，至少 $n-k$ 个未保留观测则进入分母。log 为自然对数，故 $b$ 比特计为 $b\log 2$。阈值方案取 $k=1,b=0$，组合数和为 $n+1$，得到

$$R_{\mathcal{P}}(h_S)\le\frac{\log(n+1)+\log(1/\delta)}{n-1}.$$

在 $n=100,\delta=0.05$ 时，右侧约为 0.077，即以至少 95% 的概率错误率不超过 7.7%。这是通用压缩界的充分保证，不能据此断言阈值的最优样本量需要 $\log n$ 因子。

**定理 5.11　有界样本压缩推出 PAC 可学习**　设 $(X,\mathcal{X})$ 为可测空间，$Y=\{0,1\}$ 取离散 $\sigma$ 代数，$\mathcal{H}\subseteq Y^{X}$ 是由可测分类器组成的非空集合，$k,b$ 为固定非负整数。设可测确定性映射 $\kappa,\rho$ 满足：对每份可由 $\mathcal{H}$ 正确分类的有限样本 $S=((x_i,y_i))_{i=1}^{n}$，$\kappa(S)=(S_I,u)$，其中 $I\subseteq\{1,\dots,n\}$、$|I|\le k$、$u\in\{0,1\}^{b}$；$\rho$ 只读取 $(S_I,u)$，并输出与 $S$ 一致的分类器 $\rho(S_I,u):X\to Y$。假定所有可能输出的零一损失函数均可测。则确定性学习算法 $A(S)=\rho(\kappa(S))$ 使 $\mathcal{H}$ 可实现 PAC 可学习。具体地，对任意 $\varepsilon,\delta\in(0,1)$、任意 $X\times Y$ 上的 $\mathcal{H}$ 可实现分布 $\mathcal{P}$ 和 $S\sim\mathcal{P}^{n}$，只要 $n>k$ 且

$$b\log 2+\log\left(\sum_{j=0}^{k}\binom{n}{j}\right)+\log(1/\delta)\le(n-k)\varepsilon,$$

就有 $\mathbb{P}_{S\sim\mathcal{P}^n}\{R_{\mathcal{P}}(A(S))\le\varepsilon\}\ge 1-\delta$，其中 $R_{\mathcal{P}}$ 为零一损失期望风险，且这一样本量条件不依赖具体的可实现分布 $\mathcal{P}$。

**证明**　$k=0$ 时组合数和为 1；固定 $k\ge 1$ 时，$\sum_{j=0}^{k}\binom{n}{j}\le(k+1)n^{k}$。分子至多按 $\log n$ 增长，分母按 $n$ 增长，故任意给定 $\varepsilon,\delta$ 都存在有限阈值，使此后所有 $n$ 满足条件。将这些 $n$ 代入前一定理，即得到分布无关的 PAC 风险保证。 ■

第一条定理给固定样本输出的高概率风险界，第二条保证同算法在全部可实现来源达到任意精度。二者均使用训练一致性；噪声可能破坏它，不能原样推广。压缩与重构的统计存在仍未说明如何计算或所需时间。

### 5.5.3 与 VC 维及 Rademacher 复杂度的关系

VC 维限制有限输入上的自由预测，压缩限制一致输出的重构描述。统一有界一致压缩先推出可实现 PAC，再由基本定理得到有限 VC；我们也可直接用预测计数证明这项必要限制。

**定理 5.12　压缩参数对打散的限制**　设 $X$ 为非空集合，$\mathcal{H} \subseteq \{0,1\}^X$ 非空，$k, b$ 为非负整数。假定存在固定确定性映射 $\kappa, \rho$，使每份可由 $\mathcal{H}$ 正确分类的有限样本 $S = ((x_i, y_i))_{i=1}^n$ 都被 $\kappa$ 映为 $(S_I, u)$，其中 $|I| \le k$、$u \in \{0,1\}^b$，而 $\rho$ 只根据 $(S_I, u)$ 重构一个与 $S$ 一致的二分类器。若 $\mathcal{H}$ 能打散 $m \ge 1$ 个不同输入，则

$$2^m \le 2^b \sum_{j=0}^{\min\{k,m\}} \binom{m}{j} 2^j.$$

特别地，固定有限的 $k, b$ 意味着 $\mathrm{VC}(\mathcal{H}) < \infty$。

**证明**　把被打散的 $m$ 个输入按固定次序排列，全部 $2^m$ 种标签对应可实现样本。大小 $j$ 的保留集有 $\binom{m}{j}$ 种，它的标签有 $2^j$ 种，旁信息另有 $2^b$ 种，合计为右侧的描述数。两份不同完整标签若压缩成同一描述，确定性的重构就须在某个输入给出两种标签，矛盾。故描述数至少 $2^m$。固定 $k, b$ 后，描述数随 $m$ 至多多项式增长，无法始终覆盖指数增长的 $2^m$，所以 VC 维有限。 ■

有限 VC 也给出样本量无关的压缩存在性。按 $s = k + b$ 口径，Moran 与 Yehudayoff 构造了 $d$ 维二类空间的 $s = 2^{O(d)}$ 方案[4]。通常可测条件下，它连接有限 VC、PAC 与有界压缩，但没有确定最小压缩规模。**样本压缩猜想**（sample compression conjecture）进一步要求 $s = O(d)$，Attias 等 2025 年的工作仍将一般问题列为未解决[5]。比较规模须同时计记录与旁信息，不能将描述代价藏在后者。

Rademacher 分析同时控制损失类中全部函数的随机符号波动，压缩分析则只控制固定重构映射产生的有限描述输出。前者的对象是函数值适应随机符号的能力，后者的对象是样本描述数，不要求同精度评价整个候选空间。因此 $s$ 不能直接代入 Rademacher 复杂度公式。

两条路线都约束数据选解利用偶然性的程度，方式分别是全类控制与输出信息限制。前节允许非零经验风险，本节用一致性获得固定 $k, b$ 时约

[4] S. Moran, A. Yehudayoff, *Sample Compression Schemes for VC Classes* In Journal of the ACM, 2016, vol. 63, no. 3, pp. 21:1–21:10

[5] I. Attias, S. Hanneke, A. Ramaswami, *Sample Compression Scheme Reductions* In Proceedings of the 36th International Conference on Algorithmic Learning Theory, 2025, pp. 134–162

$\log n/n$ 的界，条件不同不能仅按速率论优劣。某次样本容易压缩也不足以推出 PAC，必须有同一方案对所有可实现样本维持统一规模。

## 5.6 集成学习

单个分类器会出错，将多个分类器的回答结合起来能否减少总体错误？重复训练时，平均得分能否减小训练随机性造成的方差？投票或平均多个假设构成**集成学习**（ensemble learning）。组合可能减少得分波动，也可能表达单个假设不具备的边界；这些作用采用不同指标，不能由假设更多直接推出分类错误更少。

为区分这些指标，先固定输入与标签分析多数投票的条件错误概率，再固定输入分析平均得分的训练方差。随后用提升主动构造基假设，并以风险或间隔损失控制最终输出，才能把训练改善连接到学习保证。

### 5.6.1 投票、平均与错误相关性

以下使用 $\{-1,1\}$ 标签，得分为 0 时预测 1。取基假设 $h_t : X \to \{-1,1\}$ 与非负权重 $a_t$，满足 $\sum_t a_t = 1$，定义加权得分和最终分类器

$$f(x) = \sum_{t=1}^{T} a_t h_t(x), \qquad H(x) = \operatorname{sign}(f(x)).$$

等权 $a_t = 1/T$ 给出多数投票。允许从 $\mathcal{B}$ 选有限个基假设及上述权重，全部实值得分组成**凸包**（convex hull）$\operatorname{conv}(\mathcal{B})$。凸包的成员是得分；应用符号阈值后才得到二分类假设，二者的容量不能直接等同。

三个回答为 $(1,1,-1)$ 时，多数输出 1；真值为 1 就纠正第三者。三个都回答 $-1$ 时，共同错误却保留。投票收益因而取决于错误是否重合，下面的理想条件用独立错误给出充分保证。

**定理 5.13　独立错误下的多数投票**　设 $(X,\mathcal{X})$ 为可测空间，$Y = \{-1,1\}$，$\mathcal{P}$ 为 $X \times Y$ 上的联合分布，$T \geq 1$ 为奇数，$\gamma \in (0,1/2)$。训练样本、重采样和算法内部随机位共同构成训练随机性；设它们产生可测分类器 $h_1,\dots,h_T : X \to Y$。对 $\mathcal{P}$ 几乎处处的 $(x,y)$，假定错误指标 $E_t = \mathbb{I}\{h_t(x) \neq y\}$ 在给定 $(x,y)$ 后关于训练随机性相互独立，且 $\mathbb{E}_{\text{train}}[E_t \mid x,y] \leq 1/2-\gamma$。定义等权多数投票 $H(x) = \operatorname{sign}(\sum_{t=1}^{T} h_t(x))$，并记 $R_{\mathcal{P}}(H) = \mathbb{P}_{(x,y)\sim\mathcal{P}}\{H(x) \neq y\}$。则

$$\mathbb{E}_{\text{train}} R_{\mathcal{P}}(H) \leq e^{-2T\gamma^2}.$$

**证明** 条件于 $(x, y)$，投票错误要求 $T^{-1}\sum_t E_t \geq 1/2$，而条件均值至多为 $1/2-\gamma$。独立有界变量的 Hoeffding 不等式给出训练随机性下的错误概率 $e^{-2T\gamma^2}$。再平均 $(x, y) \sim \mathcal{P}$，即得期望风险界。 ■

定理要求每个输入处有统一条件优势且错误条件独立。每个基假设只有总体风险小于 $1/2$，可能仍在难输入上共同失败，不能据此使用定理。零协方差也不足以替代 Hoeffding 所需独立性。因此该结论解释理想条件下的投票机制，尚未给任意集成算法的风险保证。

多个基假设可以用训练扰动产生。**装袋法**（bootstrap aggregating, bagging）对原样本有放回地重采样，分别训练后平均得分或投票，试图降低样本扰动造成的预测变化。在固定 $x$ 处，设得分 $F_t(x)$ 各有方差 $v$、两两协方差为 $c$，展开平均值方差得到

$$\operatorname{Var}\left(\frac{1}{T}\sum_t F_t(x)\right) = \frac{v}{T} + \frac{T-1}{T}c.$$

$c=0$ 时方差降至 $v/T$，$c=v$ 时则不降低。随机性来自训练数据与过程，各次重采样共享原样本，不能据此认定得分无条件独立。分类还依赖得分是否跨过 0，得分方差降低也不能自动推出零一风险降低。随机森林另随机选择分裂特征，以形成预测不同的基假设，具体算法留待模型章节[6]。

[6] S. Shalev-Shwartz, S. Ben-David, *Understanding Machine Learning: From Theory to Algorithms*, Cambridge University Press, 2014, 1st ed.

### 5.6.2 弱学习与提升

第 4章的弱学习只要求统一的固定优势：任意可实现分布下，同一算法以高概率输出风险至多 $1/2-\gamma$ 者，$\gamma \in (0, 1/2)$ 不随分布变化。要把这个固定误差降到任意精度，**提升**（boosting）反复调用学习器并重新分配对样本的关注，让各轮规则补偿此前的错误。

重新加权相当于向学习器提出新的分类分布。它必须在这些允许的可实现分布上都保持同一优势，只在原来源略优于猜测不能支持提升。优势可以小，但不能在某轮改变分布后消失。

### 5.6.3 经验风险

AdaBoost 以非负样本权重实现这种关注变化。每轮增大错分者的相对权重，所学假设再参加最终加权投票。更新规则可证明经验风险下降，最终投票是否泛化仍需另给总体风险控制。

沿用 $-1,1$ 标签，$y_i h_t(x_i)=1$ 表示分对，$-1$ 表示分错。初始化 $D^{(1)}(i)=1/n$，并以 $D^{(t)}$ 表示第 $t$ 轮总和为 1 的样本权重。获得 $h_t$ 后计算 $e^{(t)}=\sum_i D^{(t)}(i)\mathbb{I}\{h_t(x_i)\neq y_i\}$。若 $0<e^{(t)}<1/2$，更新为

$$\alpha^{(t)}=\frac{1}{2}\log\frac{1-e^{(t)}}{e^{(t)}},\qquad D^{(t+1)}(i)=\frac{D^{(t)}(i)e^{-\alpha^{(t)}y_i h_t(x_i)}}{Z^{(t)}},\tag{5.23}$$

其中 $Z^{(t)}=\sum_i D^{(t)}(i)e^{-\alpha^{(t)}y_i h_t(x_i)}$ 将新权重归一化。$e^{(t)}=0$ 时已全样本一致，可输出 $h_t$ 并停止；$e^{(t)}\geq 1/2$ 时未取得所需优势。预先固定平局规则后，最终分类器为 $H_T(x)=\operatorname{sign}(\sum_t \alpha^{(t)}h_t(x))$。

更新中，错分样本乘 $e^{\alpha^{(t)}}$，分对者乘 $e^{-\alpha^{(t)}}$，前者的相对权重增加。下一轮若要维持加权错误小于 $1/2$，就要处理此前的失败样本。$e^{(t)}$ 越小，投票系数 $\alpha^{(t)}$ 越大，表明该轮获得更多最终权重。

若四个样本各重 $1/4$，本轮只错第一个，便有 $e^{(t)}=1/4$、$\alpha^{(t)}=\frac{1}{2}\log 3$。归一化后第一者重 $1/2$，其他各 $1/6$。继续错第一个就已用掉一半权重，下一轮须改变判断才能获得严格低于 $1/2$ 的错误率。

**定理 5.14　AdaBoost 经验风险界**　设 $T,n\geq 1$，$S=((x_i,y_i))_{i=1}^n$ 且 $y_i\in\{-1,1\}$。AdaBoost 初始化 $D^{(1)}(i)=1/n$；第 $t$ 轮取得 $h_t: X\to\{-1,1\}$ 后计算

$$e^{(t)}=\sum_{i=1}^{n} D^{(t)}(i)\mathbb{I}\{h_t(x_i)\neq y_i\}.$$

若每轮均有 $0<e^{(t)}<1/2$，则令

$$\alpha^{(t)}=\frac{1}{2}\log\frac{1-e^{(t)}}{e^{(t)}},\qquad Z^{(t)}=\sum_{i=1}^{n} D^{(t)}(i)e^{-\alpha^{(t)}y_i h_t(x_i)},$$

$$D^{(t+1)}(i)=\frac{D^{(t)}(i)e^{-\alpha^{(t)}y_i h_t(x_i)}}{Z^{(t)}},\qquad H_T(x)=\operatorname{sign}\left(\sum_{t=1}^{T}\alpha^{(t)}h_t(x)\right),$$

其中得分为 0 时采用预先固定的平局规则。记 $\gamma^{(t)}=1/2-e^{(t)}$，并以零一损失定义 $\hat{R}_S(H_T)=n^{-1}\sum_i \mathbb{I}\{H_T(x_i)\neq y_i\}$，则

$$\hat{R}_S(H_T)\leq\prod_{t=1}^{T}Z^{(t)}=\prod_{t=1}^{T}2\sqrt{e^{(t)}(1-e^{(t)})}\leq\exp\left(-2\sum_{t=1}^{T}(\gamma^{(t)})^2\right).\tag{5.24}$$

**证明** 展开权重递推可得 $D^{(T+1)}(i) = n^{-1}\exp(-y_i\sum_t \alpha^{(t)}h_t(x_i))/\prod_t Z^{(t)}$。样本 $i$ 若被分错，带符号得分不大于 0，指数项至少为 1。对全部样本求和，利用 $\sum_i D^{(T+1)}(i)=1$，便将经验错误率上界为 $\prod_t Z^{(t)}$。按分对、分错两组计算 $Z^{(t)} = 2\sqrt{e^{(t)}(1-e^{(t)})}$，再用 $\sqrt{1-4(\gamma^{(t)})^2} \le e^{-2(\gamma^{(t)})^2}$ 得到末界。 ■

### 5.6.4 可学习性

各轮 $e^{(t)} \le 1/2-\gamma$ 时，$T \ge \log(2/\varepsilon)/(2\gamma^2)$ 由定理 5.14保证经验风险至多 $\varepsilon/2$。要控制总体风险，还须计入样本选择基假设与权重的偏差。候选不必有限，只需在有限输入上具有受控预测数。

例如无限实数阈值在 $m$ 个互异且有序的输入上恰有 $m+1$ 种预测。选择 $T$ 个阈值所得预测列至多 $(m+1)^T$ 种，并不按无限多个阈值数值计数。一般基空间可同样用生长函数限制这些列。

令预先固定的基空间为 $\mathcal{B}\subseteq\{-1,1\}^X$，$\mathcal{V}_T$ 为 $T$ 个基假设以任意实数权重形成的投票分类器，固定平局规则。将标签重新编码为 0、1 不改变预测计数，仍可使用前述生长函数与 VC 维。分析沿用第 4.1节的可测和可分约定。

**定理 5.15 投票假设空间的生长函数** 设 $X$ 为非空集合，$\mathcal{B}\subseteq\{-1,1\}^X$ 非空。对整数 $T\ge 1$，令 $\mathcal{V}_T$ 包含所有形如

$$x \mapsto \operatorname{sign}\left(\sum_{t=1}^{T} a_t h_t(x)\right), \qquad h_t\in\mathcal{B},\quad a_1,\dots,a_T\in\mathbb{R},$$

的投票分类器，并预先固定得分为 0 时的标签。对任意二分类函数空间 $\mathcal{F}$，定义

$$\Pi_{\mathcal{F}}(m)=\max_{x_1,\dots,x_m\in X}\left|\{(f(x_1),\dots,f(x_m)) : f\in\mathcal{F}\}\right|.$$

则对任意整数 $m\ge T+1$，有

$$\Pi_{\mathcal{V}_T}(m)\le \Pi_{\mathcal{B}}(m)^T\left(\frac{em}{T+1}\right)^{T+1}. \tag{5.25}$$

若 $d=\mathrm{VC}(\mathcal{B})$ 满足 $1\le d<\infty$，则在 $m\ge \max\{d,T+1\}$ 时，

$$\log\Pi_{\mathcal{V}_T}(m)\le dT\log\frac{em}{d}+(T+1)\log\frac{em}{T+1}. \tag{5.26}$$

特别地，对每个固定有限的 $T$，$\mathcal{V}_T$ 的 VC 维有限。

**证明**　固定 $m$ 个输入，每个基假设产生至多 $\Pi_{\mathcal{B}}(m)$ 种预测，$T$ 列组成的预测矩阵因而至多 $\Pi_{\mathcal{B}}(m)^T$ 种。对固定矩阵，将输入表示为 $(h_1(x),\dots,h_T(x))\in\mathbb{R}^T$，改变权重就是改变其上的线性分类器。该类包含于 VC 维为 $T+1$ 的仿射半空间类，Sauer–Shelah 引理将每个矩阵上的预测数控制为 $(em/(T+1))^{T+1}$。乘上矩阵数即得第一式。

基类 VC 维为 $d$ 时，代入 $\Pi_{\mathcal{B}}(m)\le(em/d)^d$ 再取对数得到第二式。固定 $d,T$ 后，上界对 $m$ 至多多项式增长，不能达到任意大 $m$ 所需的 $2^m$，投票类因而具有有限 VC 维。$d=0$ 时基类各点预测唯一，仍可由第一式作同样判断。 ■

有限输入计数也包含有限基空间的情况：代入 $\Pi_{\mathcal{B}}(m)\le|\mathcal{B}|$，就出现 $T\log|\mathcal{B}|$ 项。无限但有限 VC 的基空间同样使固定轮数投票类一致收敛，有限基空间并非提升的必要条件。

**定理 5.16　有限 VC 维基假设空间下的弱学习提升**　设 $(X,\mathcal{X})$ 为可测空间，$Y=\{-1,1\}$，目标假设空间 $\mathcal{H}\subseteq Y^X$ 与固定基假设空间 $\mathcal{B}\subseteq Y^X$ 均由可测分类器组成且非空，并采用零一损失 $R_Q(h)=\mathbb{P}_{(x,y)\sim Q}\{h(x)\neq y\}$。假定 $\mathrm{VC}(\mathcal{B})<\infty$，允许 $|\mathcal{B}|=\infty$；对每个固定整数 $T\ge1$，由 $T$ 个基假设和任意实权重形成、采用固定平局规则的投票空间，其零一损失函数均可测，并存在可数损失子类，使每个投票损失函数都是该子类中某个函数序列的逐点极限。假设存在同一个弱学习器 $A$、固定的 $\gamma\in(0,1/2)$ 和样本量函数 $m_{\mathrm{weak}}:(0,1)\to\mathbb{N}$，使得对每个 $\mathcal{H}$ 可实现分布 $Q$、每个 $\eta\in(0,1)$ 及每个 $m\ge m_{\mathrm{weak}}(\eta)$，用 $S_{\mathrm{weak}}\sim Q^m$ 训练 $A$ 时，以至少 $1-\eta$ 的概率输出 $h\in\mathcal{B}$，且 $R_Q(h)\le1/2-\gamma$；概率同时包含样本抽取和 $A$ 的内部随机性。对任意 $\varepsilon,\delta\in(0,1)$，令 $T=\lceil\log(2/\varepsilon)/(2\gamma^2)\rceil$。从 $\mathcal{H}$ 可实现分布 $\mathcal{P}$ 抽取原样本 $S\sim\mathcal{P}^n$，初始化 $D^{(1)}(i)=1/n$；第 $t$ 轮从 $D^{(t)}$ 给出的加权经验分布独立抽取 $m_{\mathrm{weak}}(\delta/(2T))$ 个观测并调用 $A$。若所得 $h_t$ 的加权错误率为 $0$，直接输出 $h_t$；若错误率在 $(0,1/2)$ 内，则取 $\alpha^{(t)}=\frac12\log((1-e^{(t)})/e^{(t)})$ 并按 $D^{(t+1)}(i)\propto D^{(t)}(i)e^{-\alpha^{(t)}y_ih_t(x_i)}$ 更新权重；不满足这两种情况时按固定规则输出。完成 $T$ 轮后输出 $\mathrm{sign}(\sum_{t=1}^{T}\alpha^{(t)}h_t)$。则存在不依赖 $\mathcal{P}$ 的 $n_0(\varepsilon,\delta)$，使每个 $n\ge n_0$ 时，该构造以至少 $1-\delta$ 的概率输出零一损失期望风险不超过 $\varepsilon$ 的分类器。概率同时来自原样本、各轮重新抽样及 $A$ 的内部随机性；输出允许不属于 $\mathcal{H}$。

**证明** 给定 $\varepsilon,\delta$，先于原样本抽取固定 $T=\lceil \log(2/\varepsilon)/(2\gamma^2)\rceil$。定理 5.15保证 $\mathcal{V}_T$ 的 VC 维有限，因此可选分布无关的原样本量 $n$，使下列共同偏差事件的概率至少为 $1-\delta/2$：

$$\sup_{H\in\mathcal{V}_T}\left|R_{\mathcal{P}}(H)-\hat{R}_S(H)\right|\le \varepsilon/2.$$

原样本几乎必然由某 $h\in\mathcal{H}$ 实现，重加权只改概率而不改标签，所以每轮经验分布仍可实现。条件于样本及此前结果，独立重采样 $m_{\mathrm{weak}}(\delta/(2T))$ 条再调用弱学习器，以至少 $1-\delta/(2T)$ 的条件概率得到加权风险至多 $1/2-\gamma$。对轮次加失败概率，全部实际调用轮次都取得优势的概率便至少 $1-\delta/2$。

两类成功事件相交时，经验风险至多 $\varepsilon/2$ 且输出在 $\mathcal{V}_T$ 内，期望风险便至多 $\varepsilon$。若提前找到零经验风险基假设，将其他权重取零也使它属于 $\mathcal{V}_T$。两类失败预算相加至多 $\delta$，包含原样本、重抽样及内部随机性，故得到 PAC 保证。 ■

这项构造可处理无限基空间，依靠的是有限 VC 与全可实现分布上的统一弱优势。有限 VC 并不单独保证能够弱学任意目标空间 $\mathcal{H}$，优势条件须另证；各轮错误也没有被假定独立[7]。

证明先按精度固定 $T$，再选充分样本量。无限 VC 基空间，或固定样本量任意增轮，都不能直接套这个结论；经验损失继续下降仍需额外复杂度控制。噪声还可能使某轮重加权分布失去弱优势，故可实现提升不能原样改成不可知保证。

[7] S. Shalev-Shwartz, S. Ben-David, *Understanding Machine Learning: From Theory to Algorithms*, Cambridge University Press, 2014, 1st ed.

### 5.6.5 估计期望风险

轮数计数可能高估实际投票的复杂度，可以改看归一化得分 $f=\sum_t a_t h_t$。其间隔 $yf(x)$ 是正确权重减错误权重：正确权重 0.9 给间隔 $0.8,0.51$ 给 0.02。两者预测均正确，后者更接近改变符号的边界。这让我们用 Rademacher 复杂度研究投票的具体函数值。

对固定输入样本 $S_X=(x_1,\dots,x_n)$ 和非空有界基函数类 $\mathcal{B}$，有限非负归一化加权不会增大单侧 Rademacher 复杂度：

$$\widehat{\mathfrak{R}}_{S_X}(\mathrm{conv}(\mathcal{B}))=\widehat{\mathfrak{R}}_{S_X}(\mathcal{B})$$

（可参考第一卷“随机变量”章的凸组合 Rademacher 复杂度定理）。这里控制的是归一化得分，而不是取符号后的分类器。接下来通过间隔损失把这项得分控制转为零一风险保证。

在抽样前固定 $\rho > 0$，使用前述支配零一损失、得分 Lipschitz 常数为 $1/\rho$ 的 $\ell_\rho$。收缩引理将得分凸包的复杂度转为损失复杂度，再用经验 Rademacher 风险界，便以至少 $1-\delta$ 的概率对所有 $f \in \operatorname{conv}(\mathcal{B})$ 同时得到

$$R^{01}_{\mathcal{P}}(\operatorname{sign} f) \le \frac{1}{n}\sum_i \ell_\rho(f(x_i), y_i) + \frac{2}{\rho}\widehat{\mathfrak{R}}_{S_X}(\mathcal{B}) + 3\sqrt{\frac{\log(2/\delta)}{2n}}. \tag{5.27}$$

固定标签乘 $y_i$ 保持符号分布，故复杂度在输入样本上计算。这个链条先控制实值得分，再经间隔损失控制风险，没有直接把凸包复杂度等同于阈值分类类的复杂度。

凸包等式未依赖基假设总数，故上界也可用于无限基类。例如 $\mathcal{B} \subseteq \{-1,1\}^X$、VC 维 $d$ 满足 $1 \le d \le n$ 时，固定样本上的每个预测向量欧氏范数为 $\sqrt{n}$；应用有限向量类的 Rademacher 界及 Sauer–Shelah 引理，得到

$$\widehat{\mathfrak{R}}_{S_X}(\mathcal{B}) \le \sqrt{\frac{2\log \Pi_{\mathcal{B}}(n)}{n}} \le \sqrt{\frac{2d\log(en/d)}{n}}.$$

无限多个函数在固定样本上的表现因而可由有限预测数控制。代入式 (5.27)，复杂度项至多为 $\frac{2}{\rho}\sqrt{2d\log(en/d)/n}$。无限 VC 维时不能使用这一替换，原始经验 Rademacher 界仍成立，但须实际得到足够小的复杂度才能提供有效风险保证。

式 (5.27)不显式依赖 $T$。固定基空间后，增轮若改善归一化样本间隔，可能降低这个界；它没有保证间隔一定改善，或集成一定胜单模型。可用的统计保证仍须组合规则、基复杂度及错误/间隔共同支持，计算代价另随轮数和各基假设的训练预测时间增长。

## 5.7 可计算 PAC 学习

统计界给出足量样本下的选解保证，$\arg\min_{h\in\mathcal{H}} \hat{R}_S(h)$ 却只写明目标，没有寻找目标的步骤。有限 VC 不自动给程序，压缩存在也不自动给快速重构。接下来分别检查训练与预测能否停机，以及完成所需资源。

### 5.7.1 统计保证与程序实现

数据与假设须先有计算表示。布尔向量和自然数可用有限比特串，实数则要另定有理编码、精度或访问模型。即使维数相同，长数值也增加成本，不能只数观测。本节可计算性用 $X = \mathbb{N}$ 及每个输入停机返回 0/1 的程序，高效例子再用有限维布尔输入。

**定义 5.17 可计算 PAC 学习** 设 $\mathcal{H} \subseteq \{0,1\}^{\mathbb{N}}$。若存在一个对每份有限带标签样本 $S$ 都停机的程序 $A$，输出一个总可计算二分类假设的程序编码，并且对任意 $\varepsilon, \delta \in (0,1)$ 存在有限的 $m(\varepsilon,\delta)$，使所有 $n \geq m(\varepsilon,\delta)$ 及所有分布 $\mathcal{P}$ 均满足

$$\mathbb{P}_{S\sim\mathcal{P}^n}\left\{R_{\mathcal{P}}(A(S)) \leq \inf_{h\in\mathcal{H}} R_{\mathcal{P}}(h) + \varepsilon\right\} \geq 1-\delta,$$

则称 $\mathcal{H}$ 是不可知**可计算 PAC 可学习的**（computably PAC learnable, CPAC）。将分布限制为 $\mathcal{H}$ 可实现分布，并将右侧风险要求改为 $R_{\mathcal{P}}(A(S)) \leq \varepsilon$，得到可实现版本。

总可计算要求输出程序对每个自然数停机。输出必须在 $\mathcal{H}$ 时称恰当，允许其他可计算规则则称非恰当。当前定义只要求充分样本量存在；再要求由 $\varepsilon, \delta$ 算出上界，得到文献的 strong CPAC。这里 strong 指样本上界的有效性，不是提升中任意精度的强学习。

有限可执行列表可逐项求经验风险并选最小者。无限可枚举空间却没有“检查完”的时刻，尤其在噪声样本中，后续假设仍可能降低当前最小值。因此能列举假设并不等于能在有限时间计算 ERM。

**定理 5.18 可计算 ERM 给出的学习保证** 在离散空间 $X = \mathbb{N}$、$Y = \{0,1\}$ 上采用零一损失。设非空假设空间 $\mathcal{H} \subseteq Y^X$ 满足 $d = \mathrm{VC}(\mathcal{H}) < \infty$，并存在确定性程序 $A$，它对每份有限带标签样本 $S = ((x_i, y_i))_{i=1}^n$ 都停机，输出 $A(S) \in \mathcal{H}$ 的程序编码；该输出程序对每个 $x \in \mathbb{N}$ 都停机，且

$$\hat{R}_S(A(S)) = \min_{h\in\mathcal{H}} \frac{1}{n}\sum_{i=1}^{n} \mathbb{I}\{h(x_i) \neq y_i\}.$$

则存在可计算的样本量上界 $m(d,\varepsilon,\delta)$，使任意 $\varepsilon, \delta \in (0,1)$、任意 $\mathbb{N}\times Y$ 上的联合分布 $\mathcal{P}$、任意 $n \geq m(d,\varepsilon,\delta)$ 及 $S \sim \mathcal{P}^n$ 均满足

$$\mathbb{P}_{S\sim\mathcal{P}^n}\left\{R_{\mathcal{P}}(A(S)) \leq \inf_{h\in\mathcal{H}} R_{\mathcal{P}}(h) + \varepsilon\right\} \geq 1-\delta,$$

其中 $R_{\mathcal{P}}$ 为零一损失期望风险。因此，$\mathcal{H}$ 恰当地不可知 CPAC 可学习，且具有可计算的样本量上界；概率仅来自独立同分布样本。

**证明** 取题设 ERM 程序 $A$。有限 VC 维提供分布无关的一致收敛样本量；设偏差容限 $\varepsilon/2$，在共同事件上比较任意 $h \in \mathcal{H}$：

$$R_{\mathcal{P}}(A(S)) \leq \hat{R}_S(A(S)) + \varepsilon/2 \leq \hat{R}_S(h) + \varepsilon/2 \leq R_{\mathcal{P}}(h) + \varepsilon.$$

对参照 $h$ 取下确界即得风险保证。VC 偏差界显式依赖 $d, \varepsilon, \delta$；对固定空间，把一个有限 VC 上界作为常数写入程序即可计算足够样本量。训练与输出程序的停机性则分别由题设保证。 ■

固定有限 VC 上界可写入证明中的样本程序，并未提供从任意类的程序描述自动算 VC 的方法。存在一个针对该空间的程序，与从任意描述统一构造它，是不同要求。

### 5.7.2 有效 VC 维

普通 VC 为 $d$ 只保证 $d+1$ 个不同输入上有一种预测缺失。计算程序还须根据输入在有限时间找出缺失向量。**有效 VC 维**（effective VC dimension）为这一存在性增加统一可执行的见证要求。

**定义 5.19　有效 VC 维**　对 $\mathcal{H} \subseteq \{0,1\}^{\mathbb{N}}$，若存在总可计算映射 $W$，使任意 $d+1$ 个互异输入 $x_1, \dots, x_{d+1}$ 都满足

$$W(x_1, \dots, x_{d+1}) \in \{0,1\}^{d+1} \setminus \{(h(x_1), \dots, h(x_{d+1})) : h \in \mathcal{H}\},$$

则称 $d$ 为有效 VC 维的一个上界。所有这样的非负整数 $d$ 中的最小值记为 $\mathrm{eVC}(\mathcal{H})$；若不存在，则记为 $\infty$。

$W$ 只返回一种缺失预测，不必列完所有可能者。自然数递增阈值在两个不同点上不能让小者为 1、大者为 0，比较大小即可停机返回该向量，故有效维至多 1。一个输入又可分别取 0 与 1，普通维及有效维遂都为 1。

**定理 5.20　普通 VC 维与有效 VC 维的比较**　设 $\mathcal{H} \subseteq \{0,1\}^{\mathbb{N}}$ 非空。把 $\mathrm{eVC}(\mathcal{H})$ 定义为满足以下条件的最小非负整数 $d$：存在总可计算映射 $W$，对任意 $d+1$ 个互异自然数 $x_1, \dots, x_{d+1}$，都有

$$W(x_1, \dots, x_{d+1}) \in \{0,1\}^{d+1} \setminus \{(h(x_1), \dots, h(x_{d+1})) : h \in \mathcal{H}\};$$

若不存在这样的 $d$，则令 $\mathrm{eVC}(\mathcal{H}) = \infty$。于是 $\mathrm{VC}(\mathcal{H}) \le \mathrm{eVC}(\mathcal{H})$。若普通 VC 维有限，且存在一个对每份有限带标签样本都停机的程序，输出 $\mathcal{H}$ 中对每个自然数输入都停机、且零一经验风险最小的假设，则两者相等。

**证明** 有效见证对任意 $d+1$ 个输入返回不可实现标签，因此这些输入均不能打散，普通 VC 维至多为 $d$。

设普通 VC 维 $d < \infty$。给定 $d+1$ 个互异输入，逐一枚举 $2^{d+1}$ 种标签，运行 ERM 并计算其经验风险；各步骤都停机。至少一种标签不可实现，其最小经验风险为正，ERM 也必须返回正风险。输出第一个这样的标签便构成总可计算见证，故有效 VC 维至多为 $d$。与前一方向合并，得到相等。 ■

在所述自然数输入、总可计算输出模型中，Delle Rose 等证明了非恰当不可知 CPAC 当且仅当有效 VC 有限[8]。充分性需要另构造可计算学习器，普通 VC 的一致收敛不足以替代。这里使用外部刻画说明有效见证的作用，完整计算论证明见原文。

非恰当输出是刻画条件，改成恰当或要求可计算样本上界，不能直接继承。$\mathrm{VC}(\mathcal{H}) \le \mathrm{eVC}(\mathcal{H})$ 保证有效有限推出普通有限，逆向一般还缺计算条件。研究中的有限普通 VC 但无非恰当 CPAC 类，因而具有无限有效 VC：样本信息足够，执行程序仍可能不存在[9]。这种不可计算与下一节的缓慢计算不同。

[8] V. Delle Rose, A. Kozachinskiy, C. Rojas, T. Steifer, *Find a Witness or Shatter: The Landscape of Computable PAC Learning* In Proceedings of the 36th Conference on Learning Theory, 2023, pp. 511–524

[9] V. Delle Rose, A. Kozachinskiy, C. Rojas, T. Steifer, *Find a Witness or Shatter: The Landscape of Computable PAC Learning* In Proceedings of the 36th Conference on Learning Theory, 2023, pp. 511–524

### 5.7.3 高效学习与优化误差

停机程序仍可能慢到无法使用。高效 PAC 还要求样本、训练和预测资源是规模参数的多项式。变量须包括问题规模 $p$、数据及输出编码、$1/\varepsilon$、$\log(1/\delta)$，有时还包括目标描述长。无限精度实数一步与比特计费属于不同模型，资源界须按同一约定解释。

高效构造不一定求精确 ERM。允许经验目标距离下确界至多 $\alpha$，就可分别预算优化容差与样本估计容差。

**定理 5.21 近似 ERM 的期望风险保证** 设 $(X, \mathcal{X})$ 为可测空间，$Y = \{0,1\}$，$\mathcal{H} \subseteq Y^X$ 是由可测分类器组成的非空假设空间，$\mathcal{P}$ 是 $X \times Y$ 上的联合分布，$n \ge 1$，$S = ((x_i, y_i))_{i=1}^n \sim \mathcal{P}^n$。采用零一损失，并记

$$R_{\mathcal{P}}(h) = \mathbb{P}_{(x,y)\sim\mathcal{P}}\{h(x) \ne y\}, \qquad \hat{R}_S(h) = \frac{1}{n}\sum_{i=1}^{n} \mathbb{I}\{h(x_i) \ne y_i\}.$$

设 $\alpha, \eta \ge 0$，学习算法 $A$ 在这份样本上输出 $A(S) \in \mathcal{H}$，且 $\hat{R}_S(A(S)) \le \inf_{h\in\mathcal{H}} \hat{R}_S(h) + \alpha$。若该样本满足 $\sup_{h\in\mathcal{H}} |R_{\mathcal{P}}(h) - \hat{R}_S(h)| \le \eta$，则

$$R_{\mathcal{P}}(A(S)) \le \inf_{h\in\mathcal{H}} R_{\mathcal{P}}(h) + 2\eta + \alpha.$$

**证明**　固定任意参照 $h \in \mathcal{H}$，依次用输出偏差、经验近似最优性和参照偏差：

$$R_{\mathcal{P}}(A(S)) \le \hat{R}_S(A(S)) + \eta \le \hat{R}_S(h) + \alpha + \eta \le R_{\mathcal{P}}(h) + \alpha + 2\eta.$$

对任意参照成立，取下确界即得结论。 ■

$2\eta$ 由两次总体/经验比较产生，$\alpha$ 由求解容差产生。取 $\eta = \varepsilon/4$、$\alpha = \varepsilon/2$ 即使总超额至多 $\varepsilon$。若样本和近似训练时间均为约定参数的多项式，且输出长度与预测时间也受控，就有高效不可知 PAC 的充分路线。某精确 ERM 很难，还没有排除其他近似或非恰当算法。

### 5.7.4 从枚举到有效算法

看布尔合取怎样利用结构。输入 $\boldsymbol{x} \in \{0,1\}^p$，文字为 $x_j$ 或 $1 - x_j$，所选文字全为 1 时预测 1，否则预测 0。每坐标选正、负或不选，无矛盾合取至多 $3^p$，另加恒 0 得到 $\mathcal{C}_p$。有限空间样本界仅线性依赖 $p$，枚举则检查指数候选，区别来自求解方式。

可实现样本可直接构造一致合取。先保留 $2p$ 个文字，扫描每个正例，删掉在它处为 0 的文字，再输出剩余合取。删空时预测恒 1；无正例时预测恒 0。操作只需要扫描样本，不逐个列候选。

**定理 5.22　布尔合取的高效可实现学习**　设 $p, n \ge 1$，$X = \{0,1\}^p$、$Y = \{0,1\}$ 均取离散 $\sigma$ 代数，$\mathcal{C}_p$ 由 $X$ 上的无矛盾布尔合取（包括空合取给出的恒为 1 假设）及恒为 0 假设组成。对样本 $S = ((\boldsymbol{x}_i, y_i))_{i=1}^n$，确定性学习算法先保留全部 $2p$ 个正、负文字；每读到一个正例，便删除在该输入上取 0 的文字；若样本没有正例则输出恒为 0，否则输出剩余文字的合取，没有剩余文字时输出恒为 1。该算法在 $\mathcal{C}_p$ 可实现的样本上输出与样本一致的假设，训练时间为 $O(np)$，预测时间为 $O(p)$。若 $\mathcal{P}$ 是 $X \times Y$ 上的联合分布，存在 $h^\star \in \mathcal{C}_p$ 满足 $\mathbb{P}_{(x,y)\sim\mathcal{P}}\{h^\star(x) \ne y\} = 0$，且 $S \sim \mathcal{P}^n$，则对任意 $\varepsilon, \delta \in (0,1)$，只要

$$n \ge \frac{\log(3^p + 1) + \log(1/\delta)}{\varepsilon},$$

就以关于 $S \sim \mathcal{P}^n$ 至少 $1 - \delta$ 的概率输出零一损失期望风险不超过 $\varepsilon$ 的假设。

**证明** 无正例时恒为 0 与样本一致。有正例时，目标合取的文字在所有正例上都为 1，不会被删除；剩余文字也全在正例上为 1，故输出分对全部正例。任意负例上，目标合取至少一个文字为 0，这个文字仍被保留，输出也为 0。由此输出与全样本一致。每条观测检查至多 $2p$ 个文字，训练耗时 $O(np)$；有正例时剩余文字不矛盾且最多 $p$ 个，预测耗时 $O(p)$。把 $|\mathcal{C}_p| \le 3^p + 1$ 代入有限类可实现样本界，即得风险保证。 ■

该例子同时提供样本界、实际步骤与运行成本。可实现性是保留目标文字的依据；噪声正例可能错删必要文字，原一致证明随之失效。改变标签设定后，还须重新分析优化和统计条件。

## 5.8 本章小结

二分类的风险控制必须覆盖数据选解，而不能仅评价预定假设。有限空间以失败概率求和，无限空间改数有限输入上的预测，经 Sauer–Shelah 及对称化得到共同偏差。在本章可测及列明条件下，有限 VC、一致收敛、可实现和不可知 PAC 等价。

定性刻画之外，风险界还可以利用实际函数值或输出描述。Rademacher 与高斯量考察随机波动拟合，压缩考察重构保留的信息。投票还需控制基空间、组合与训练；无限基空间未必有碍，训练改善却不独自证明泛化。各界的条件和对象不同，表达式简短不能证明总是更紧。

有限普通 VC、可计算学习与多项式资源分别回答统计、停机与成本。有效 VC 连接计算见证，输出表示及预测代价仍须在高效层核算。多分类保留这些区别，却不再普遍由单一维度同时刻画一致收敛与学习。

**延伸阅读** Bartlett 与 Mendelson 的论文继续推导依赖样本的 Rademacher 与高斯风险界，并研究组合函数类怎样继承基函数类的复杂度，适合接着线性得分和集成部分阅读[10]。

Moran 与 Yehudayoff 的压缩构造可与本章两条方向对照：原文由有限 VC 得到压缩，本章由已有压缩得到风险界。表示存在、表示大小及有效求解分别需要证据[11]。

Delle Rose 等的有效 VC 研究可用于对照普通 PAC、CPAC 及要求有效样本上界的版本[12]。这些区别说明统计基本定理给出了存在性条件，仍未给出全部程序步骤。

[10] P. L. Bartlett, S. Mendelson, *Rademacher and Gaussian Complexities: Risk Bounds and Structural Results* In Journal of Machine Learning Research, 2002, vol. 3, pp. 463–482

[11] S. Moran, A. Yehudayoff, *Sample Compression Schemes for VC Classes* In Journal of the ACM, 2016, vol. 63, no. 3, pp. 21:1–21:10

[12] V. Delle Rose, A. Kozachinskiy, C. Rojas, T. Steifer, *Find a Witness or Shatter: The Landscape of Computable PAC Learning* In Proceedings of the 36th Conference on Learning Theory, 2023, pp. 511–524

第 6 章

# 多分类学习的可学习性

一个二分类假设改答时，只剩另一种标签可选；多分类却可能改成多个不同答案。候选在有限输入上的组合因此增加，前章将可学习性与一致收敛合在一起的刻画也需要重查。标签有限时，我们先扩展预测计数；允许无限标签后，分别判断全类风险估计与成功学习器是否存在；再为统计结果增加程序条件。

本章把第 4.1节的二类标签改为有限或无限 $Y$，仍观察输入标签对，使用 i.i.d. 抽样、零一风险和前章 PAC 基准。全类损失的共同估计由**图维**（graph dimension）描述，成功学习器的存在由**DS 维**（Daniely–Shalev-Shwartz dimension）描述。一般多分类允许输出空间 $\mathcal{W}_{\text{out}}$ 超出比较类 $\mathcal{H}$，这是后述学习刻画的条件。

## 6.1 从二分类到多分类

邮件标签现在分正常、广告、诈骗，输入 $x$ 仍是特征，$h(x)$ 选择类别；与真实 $y$ 不同即计一次错误。以 $X, Y$ 为两空间、非空 $\mathcal{H} \subseteq Y^X$ 为候选，对联合来源 $\mathcal{P}$ 及 iid 样本 $S = ((x_i, y_i))_{i=1}^n$，定义 4.2与定义 4.3在零一损失下为

$$R_{\mathcal{P}}(h) = \mathbb{P}_{(x,y)\sim\mathcal{P}}\{h(x) \neq y\}, \qquad \hat{R}_S(h) = \frac{1}{n}\sum_{i=1}^{n} \mathbb{I}\{h(x_i) \neq y_i\}. \tag{6.1}$$

后文固定这一计分口径。可实现 PAC 要求零风险目标来源下输出风险小，不可知 PAC 要求接近类内下确界；量词沿用第 4.2节。统计定理仍须满足第 4.1节的可测性与可分性条件。

有限标签可先编码成二元位。例如对三类取

$$\text{正常} \longleftrightarrow (0,1), \qquad \text{广告} \longleftrightarrow (1,0), \qquad \text{诈骗} \longleftrightarrow (1,1).$$

广告邮件于是给两位任务标签 1 和 0。在同一批邮件上训练 $b_1, b_2$，新输入先得到 $(b_1(x), b_2(x))$，再按表解码；无效 $(0,0)$ 预定解为正常。这样改成两个二类任务，类别信息并未减少。

当 $2 \le K = |Y| < \infty$ 时，用 $L = \lceil \log_2 K \rceil$ 位赋互异编码 $c : Y \to \{0,1\}^L$，以 $c_j(y)$ 记第 $j$ 位。相应二类候选必须来自原空间的这一位投影：

$$\mathcal{B}_j = \{x \mapsto c_j(h(x)) : h \in \mathcal{H}\}, \qquad 1 \le j \le L.$$

每个 $h$ 先编码输出，再保留第 $j$ 位。标签虽二元，诱导类仍可复杂；二类分布无关 PAC 须有有限 VC，编码本身未保证这一容量条件。若 $K = 1$，唯一标签的常量预测已是零风险规则，无需拆分位任务。

可实现来源由 $h^\star \in \mathcal{H}$ 给零风险时，$c_j \circ h^\star$ 在每个位类中且几乎处处预测 $c_j(y)$，所以全部位任务也可实现。若每个 $\mathcal{B}_j$ 可 PAC 学习，令学得 $b_j$ 的位风险为

$$e_j = \mathbb{P}_{(x,y)\sim\mathcal{P}}\{b_j(x) \ne c_j(y)\}.$$

以 $\tilde{h}$ 记解码分类器。全部位正确必给正确类别，故类别错误包含在位错并集中：

$$R_{\mathcal{P}}(\tilde{h}) \le \sum_{j=1}^{L} e_j.$$

将位风险目标定为 $\varepsilon/L$、位学习失败预算定为 $\delta/L$，两次并集分别得到类别风险与抽样成功概率，从而以至少 $1-\delta$ 的概率使风险至多 $\varepsilon$。位学习可共享样本，错误不必独立，只需共同样本量满足

$$n \ge \max_{1 \le j \le L} m_{\mathcal{B}_j}(\varepsilon/L, \delta/L).$$

合成输出未必属于原 $\mathcal{H}$。

逐位学习在不可知情形不一定优化原任务。沿用三类编码，设输入恒定，正常、广告、诈骗的概率为 0.40、0.35、0.25，候选为三个常量假设。第一位为 1 的概率 0.60，第二位为 1 的概率 0.65，各位最优都选 1，合成诈骗后风险 0.75；直接选正常的风险却为 0.60。即使已知所有概率，逐位最优仍选错原任务的最优类别。逐位优化分别降低每个编码位的错误概率；多类零一损失只在整个标签正确时计 0，其余一律计 1。同一错误标签可能在两位上都出错，两项位损失便分别记错，而类别损失只记一次。两个优化目标因此并不相同。

有限标签编码给出算法构造，学习保证还须控制诱导二类空间并合并位风险。无限标签无法由任何固定有限位数区分，上述有限次归约也不能直接使用。要直接判断原空间，我们转而分析它在有限输入上产生的预测结构。

这里不能把“实现全部 $|Y|^m$ 种预测”作为打散要求。有些空间在各输入只用两个标签，却已包含任意大的二类难题，要求用齐所有标签反而漏掉它。我们应先固定各输入的两种答案，再问能否独立切换；Natarajan 维（Natarajan dimension）衡量可以维持这种自由选择的输入数。

## 6.2　有限标签空间及 Natarajan 维的边界

先限定 $2 \le K = |Y| < \infty$。找出独立二元选择，再用其最大规模限制预测数，便能沿用前章的对称化与 ERM 风险比较。

### 6.2.1　Natarajan 维

固定输入处的两种标签选择能够限制有限标签类的预测数。Natarajan 打散要求先为每个输入固定两个不同答案，再由类中的函数实现这组标签对的全部独立选择；标签对可以随输入改变，却不能随待实现的模式改变（可参考第一卷“计数与计算”章的 Natarajan 打散与维度定义）。本章以 $d_N(\mathcal{H})$ 记可打散有限输入集大小的上确界。

这一条件不要求标签有限。二类时各处的不同标签对只能取那两个答案，故它退化为 VC 维。维度 0 说明各输入预测唯一；可打散点集没有有限规模上界时，维度为无穷。这里继续把所得维度接到预测计数。

### 6.2.2　有限标签的一致收敛

固定输入后先合并相同预测。令

$$V(x_1, \dots, x_m) = \{(h(x_1), \dots, h(x_m)) : h \in \mathcal{H}\}.$$

再对输入选择取上确界，得到生长函数

$$\Pi_{\mathcal{H}}(m) = \sup_{(x_1,\dots,x_m)\in X^m} |V(x_1, \dots, x_m)|.$$

这与第 5.3.2节的二类计数步骤相同，区别是每坐标可取 $K$ 个标签。Sauer–Shelah 由 VC 限制二元数目，下面用 Natarajan 承担多类的对应职责。

当 $2 \le K = |Y| < \infty$ 且 $d = d_N(\mathcal{H}) < \infty$ 时，记 $q = K(K-1)/2$ 为不同无序标签对的数目。对每个整数 $m \ge 0$，有限标签的计数界给出

$$\Pi_{\mathcal{H}}(m) \le G_{d,K}(m) := \sum_{j=0}^{\min\{d,m\}} \binom{m}{j} q^j$$

（可参考第一卷“计数与计算”章的有限标签预测数目上界）。在学习问题中，$G_{d,K}(2n)$ 将控制原样本与副样本合并后的不同损失模式数，因而能够进入下一步对称化后的失败概率。

二类时 $q = 1$、$d_N = \mathrm{VC}(\mathcal{H})$，求和回到 Sauer–Shelah 的 $\sum_{j=0}^{\min\{d,m\}} \binom{m}{j}$。多类的 $q^j$ 另计每个参与二元选择的坐标所用的标签对。

固定 $d, K$ 使上界至多多项式增长。样本标签一经固定，相同预测向量也给出相同损失向量，故这个计数控制经验风险分析中的不同结果。副样本与随机交换于是可以沿用。

**定理 6.1　有限标签的一致收敛保证**　设 $(X, \mathcal{X})$ 为可测空间，离散标签空间 $Y$ 满足 $2 \le |Y| = K < \infty$，$\mathcal{H} \subseteq Y^X$ 是由可测分类器组成的非空集合，$d = d_N(\mathcal{H}) < \infty$，并令

$$G_{d,K}(m) = \sum_{j=0}^{\min\{d,m\}} \binom{m}{j} \left(\frac{K(K-1)}{2}\right)^j .$$

假定零一损失类 $\mathcal{L}_{\mathcal{H}} = \{(x,y) \mapsto \mathbb{I}\{h(x) \neq y\} : h \in \mathcal{H}\}$ 中的每个函数均可测，并存在可数子类 $\mathcal{L}_0 \subseteq \mathcal{L}_{\mathcal{H}}$，使每个 $f \in \mathcal{L}_{\mathcal{H}}$ 都是 $\mathcal{L}_0$ 中某个函数序列的逐点极限。设 $\mathcal{P}$ 为 $X \times Y$ 上的任意联合分布，$n \ge 1$，$S = ((x_i, y_i))_{i=1}^n \sim \mathcal{P}^n$，并记

$$R_{\mathcal{P}}(h) = \mathbb{P}_{(x,y)\sim\mathcal{P}}\{h(x) \neq y\}, \qquad \hat{R}_S(h) = \frac{1}{n}\sum_{i=1}^{n} \mathbb{I}\{h(x_i) \neq y_i\}.$$

则对任意 $\delta \in (0,1)$，以关于 $S \sim \mathcal{P}^n$ 至少 $1-\delta$ 的概率，

$$\sup_{h \in \mathcal{H}} |R_{\mathcal{P}}(h) - \hat{R}_S(h)| \le \sqrt{\frac{8}{n} \log \frac{4 G_{d,K}(2n)}{\delta}}. \tag{6.2}$$

**证明**　取 $\eta > 0, n\eta^2 \ge 2$。独立副样本把总体/经验偏差转成双经验风险差超过 $\eta/2$，概率最多增一倍。合并输入上的损失向量至多 $G_{d,K}(2n)$ 种；逐对随机交换后，对固定向量集中，再对这些有限向量求并集界，得到

$$\mathbb{P}\left\{\sup_{h} |R_{\mathcal{P}}(h) - \hat{R}_S(h)| > \eta\right\} \le 4 G_{d,K}(2n) e^{-n\eta^2/8}.$$

令右侧等于 $\delta$ 即可解出所列偏差；该解自动满足 $n\eta^2 \ge 2$。上界超过 1 时，零一损失的取值范围已保证结论。 ■

这里 $\mathcal{P}$ 仍是联合来源，没有要求各类别等概率。固定 $d, K, \delta$ 后，式 (6.2) 随 $n$ 趋零且统一覆盖全部允许来源，因此得到分布无关 UC。当 $1 \le d \le 2n$ 时，代入 $G_{d,K}(2n) \le q^d (2en/d)^d$ 还能看出类别数以 $\log K$ 量级进入上界。

### 6.2.3 有限标签的可学习性

共同风险估计可以覆盖样本选出的 ERM。用输出与参照各一次偏差，再结合 Natarajan 打散产生的困难来源，便得到有限标签下的双向刻画。

**定理 6.2　有限标签的可学习性刻画**　设 $(X, \mathcal{X})$ 为可测空间，离散标签空间 $Y$ 满足 $2 \le |Y| = K < \infty$，$\mathcal{H} \subseteq Y^X$ 是由可测分类器组成的非空集合，并采用零一损失。假定损失类 $\mathcal{L}_{\mathcal{H}} = \{(x, y) \mapsto \mathbb{I}\{h(x) \neq y\} : h \in \mathcal{H}\}$ 中的每个函数均可测，且存在可数子类 $\mathcal{L}_0 \subseteq \mathcal{L}_{\mathcal{H}}$，使每个 $f \in \mathcal{L}_{\mathcal{H}}$ 都是 $\mathcal{L}_0$ 中某个函数序列的逐点极限。学习算法均为可测映射，训练样本均为 $S \sim \mathcal{P}^n$，成功概率同时计入样本抽取和算法的内部随机性。在这一分布无关设定中，以下命题等价：

1. $d_N(\mathcal{H}) < \infty$；
2. 零一损失满足分布无关的一致收敛；
3. $\mathcal{H}$ 不可知 PAC 可学习；
4. $\mathcal{H}$ 可实现 PAC 可学习。

设 $d = d_N(\mathcal{H}) < \infty$，并令

$$G_{d,K}(m) = \sum_{j=0}^{\min\{d,m\}} \binom{m}{j} \left(\frac{K(K-1)}{2}\right)^j.$$

对任意 $\varepsilon, \delta \in (0,1)$、任意 $X \times Y$ 上的联合分布 $\mathcal{P}$，若 $n \ge 1$ 且

$$n \ge \frac{32}{\varepsilon^2} \log \frac{4 G_{d,K}(2n)}{\delta},$$

则任意以概率 1 输出 $A(S) \in \arg\min_{h \in \mathcal{H}} \hat{R}_S(h)$ 的可测 ERM，在 $S \sim \mathcal{P}^n$ 及其内部随机性的联合概率下，以至少 $1 - \delta$ 的概率满足

$$R_{\mathcal{P}}(A(S)) \le \inf_{h \in \mathcal{H}} R_{\mathcal{P}}(h) + \varepsilon.$$

**证明**　有限 Natarajan 维先给 UC。取偏差 $\varepsilon/2$，在共同成功事件内用 ERM 最优性比较任意 $h$：

$$\begin{aligned} R_{\mathcal{P}}(A(S)) &\le \hat{R}_S(A(S)) + \varepsilon/2 \\ &\le \hat{R}_S(h) + \varepsilon/2 \\ &\le R_{\mathcal{P}}(h) + \varepsilon. \end{aligned}$$

对参照取下确界得不可知 PAC。可实现分布属于这一允许族，因此也得到可实现 PAC。

逆向设 Natarajan 无限。任意 $n$ 都可取被打散的 $2n$ 点及各点两种固定标签，令输入均匀，目标在各标签对中独立公平选择。$n$ 次观测至多见 $n$ 点，余下标签仍公平，所以随机目标下任意算法平均风险至少 $1/4$。平均中必有固定可实现目标也达此值；再由 $R \le 1$ 及 $\mathbb{E}R \le 1/8 + (7/8)\mathbb{P}\{R > 1/8\}$，得失败概率至少 $1/7$。每个 $n$ 都存在这种来源，违反分布无关可实现 PAC。 ■

必要性证明只使用各输入固定的两个标签，没有用标签总数有限，所以任意 $Y$ 下可学习都必须有有限 Natarajan 维。有限标签承担的是另一方向的预测计数。ERM 样本式是充分条件，尚未声称匹配两类 PAC 的最优复杂度。

### 6.2.4 Natarajan 维在无限标签空间下的局限

无限 $Y$ 使 $q = \binom{K}{2}$ 不再有限，旧计数界失去作用。证明失效本身不等于维度判据失效；还须构造有限 Natarajan 维却不可学习的空间，才能否定充分性。

先在两坐标看一个有限模式：

$$(a,u),\ (b,u),\ (b,v),\ (c,v),\ (c,w),\ (a,w),$$

其中 $a,b,c$ 互异，$u,v,w$ 互异。每个向量在每坐标都有只改该坐标的邻居，例如 $(a,u)$ 的 $(b,u)$ 和 $(a,w)$。但任意两种第一标签至多共享一种第二标签，无法形成固定两对标签的四组合；Natarajan 维仅 1，两坐标却都留歧义。这一个有限类仍可学习，反例还需任意维的同类结构。

图 6.1把这六种预测的邻接关系画成环。每个顶点都连接一条只改第一坐标的边和一条只改第二坐标的边，因此两坐标上的局部歧义可以同时保留；这种邻接条件不要求固定两对标签的四种组合全部出现。

若要从二维局部歧义得到不可学习性，需要任意维的对应构造。下面把 $V_m$ 的向量视为坐标集 $\{1,\dots,m\}$ 上的函数，使其 Natarajan 维有明确对象。

**引理 6.3　低 Natarajan 维的局部邻接构造**　对每个整数 $m \ge 1$，把 $Y_m^m$ 中的向量视为定义在坐标集 $\{1,\dots,m\}$ 上的分类函数。存在非空有限标签集 $Y_m$ 及有限非空函数集合 $V_m \subseteq Y_m^{\{1,\dots,m\}}$，使

1. $d_N(V_m) = 1$；
2. 对任意 $v \in V_m$ 和 $i \in \{1,\dots,m\}$，存在 $u \in V_m$ 满足

$$u_i \ne v_i, \qquad u_j = v_j \quad (j \ne i).$$

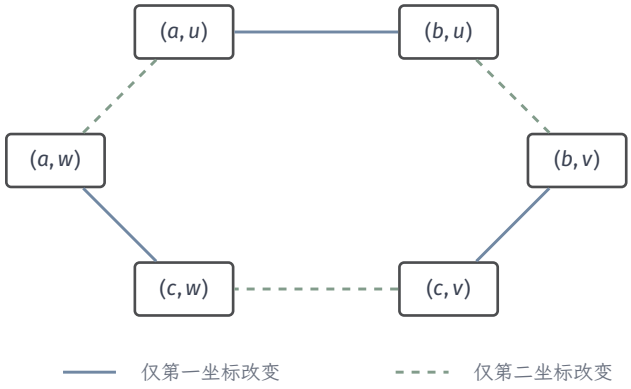


图 6.1　六种预测的坐标邻接环。顶点为上文的六个向量，蓝色实线仅改变第一坐标，绿色虚线仅改变第二坐标；边没有方向。每个顶点在两个坐标上分别有邻居，却不存在固定两对标签的完整四种组合。因而这个两输入函数类的 Natarajan 维为 1，后文分析的 DS 维为 2；它仍是可学习的有限类，不能单独证明不可学习性。

Brukhim 等的组合拓扑构造给出该引理[1]。证明未在本章展开。它同时限制固定标签对的自由选择，又保留每个向量在每个坐标的竞争答案。依靠这两项性质，下面把各维局部构造合成一个固定假设空间。

[1] N. Brukhim, D. Carmon, I. Dinur, S. Moran, A. Yehudayoff, *A Characterization of Multiclass Learnability* In Proceedings of the 63rd Annual Symposium on Foundations of Computer Science, 2022, pp. 943–955

**定理 6.4　无限标签下有限 Natarajan 维并不充分**　在输入与标签均取离散 $\sigma$ 代数、训练样本独立同分布并采用零一损失的设定中，存在可数输入空间 $X$、可数标签空间 $Y$ 和非空假设空间 $\mathcal{H} \subseteq Y^X$，使 $d_N(\mathcal{H}) = 1$，但不存在对所有 $\mathcal{H}$ 可实现联合分布都具有分布无关可实现 PAC 保证的可测学习算法。

**证明**　对各 $m$ 取引理 6.3中的 $V_m$，把输入组成互不相交的块 $C_m = \{(m,1), \ldots, (m,m)\}$，令 $X = \bigcup_{m \geq 1} C_m$。局部标签加块编号写为 $(m, y)$，因此 $(2, a)$ 与 $(3, a)$ 是不同类别。另设普通标签 $\star$ 表示不在所选块，它不同于全部 $(m, y)$，并非未知、缺失或任意值。标签总空间为

$$Y = \{\star\} \cup \bigcup_{m \geq 1} (\{m\} \times Y_m).$$

每个 $v \in V_m$ 扩展为整个输入空间上的假设

$$h_{m,v}(r, i) = \begin{cases} (m, v_i), & r = m, \\ \star, & r \neq m. \end{cases}$$

例如 $h_{2,v}$ 只在 $C_2$ 使用局部答案，其他块均答 $\star$。以全部 $h_{m,v}$ 组成 $\mathcal{H}$，各维困难块便属于同一个固定空间。

两点若在不同块，每处标签对至少含一个非 $\star$ 标签，而任一假设只在一个块输出这种标签，故无法实现两处同时非 $\star$ 的组合。两点若在同块，标签对含 $\star$ 时，一处为 $\star$ 会使该块全为 $\star$，不能独立切换；两对都不含 $\star$ 时，又要求 $V_m$ 打散两坐标，与维度 1 矛盾。单点仍可取局部标签或 $\star$，所以 $d_N(\mathcal{H}) = 1$。

对给定 $n$ 取 $m = 2n$，输入在 $C_m$ 均匀，目标从有限 $V_m$ 均匀抽取。考虑未见坐标 $i$，即使透露其他全部坐标的真实标签，该处仍有竞争答案。给定其余坐标后，不同向量在 $i$ 处必有不同标签；条件分布对这些向量均匀，邻接条件又保证至少两个。因此该处的平均错误概率至少 $1/2$。

$n$ 次抽样至少遗漏 $2n$ 点的一半，故对目标、样本及内部随机性平均的风险至少 $1/4$。有限目标平均中必有固定 $v$ 达到该下界；用 $\mathbb{E}R \le 1/8 + (7/8)\mathbb{P}\{R > 1/8\}$，再得风险超过 $1/8$ 的概率至少 $1/7$。每个样本量都有如此可实现来源，所以不存在统一 PAC 样本量。 ■

无限标签本身没有排除学习；障碍是 Natarajan 有限未排除所有困难结构。接下来把全类共同估计与成功算法存在分开，寻找各自的容量条件。

## 6.3 图维、DS 维与一般标签空间

有限标签靠 Natarajan 的预测计数连接 UC 与学习。去掉标签数有限的条件后，第 6.2.4节已给维度有限却不可学习的例子。我们因此分别问：一份样本能否同时估准所有风险，以及是否存在算法选出低风险者？前者约束整个空间，后者只约束算法输出。

零一风险只问是否匹配标签，图维因此可转为二值损失类的 VC 问题。学习器则可能利用标签携带的更多信息，DS 维用预测之间单坐标变化描述剩余歧义。先建立图维与 UC 的关系，再分析为什么存在学习器是另一项要求。

### 6.3.1 一致收敛

零一损失把无限个错误答案都计为 1，风险只看与真值是否匹配。为描述这一二元能力，我们先给每个输入固定参考答案 $f(x)$，再问能否任意指定一组匹配位置。**图打散**（graph shattering）要求对每个位置子集都有类中函数恰在这些位置匹配参考，在其余位置全部偏离参考；偏离时使用的标签可以随模式改变（可参考第一卷“计数与计算”章的图打散定义）。

可图打散有限输入集大小的上确界记为 $d_G(\mathcal{H})$（可参考第一卷“计数与计算”章的图维定义）。图打散只预定参考答案，Natarajan 打散还预定每处的替代答案，因此后者推出前者，逆向未必成立。接下来利用“匹配或偏离”的二元模式，将图维转为零一损失类的 VC 维。

风险要看匹配与否，故将各假设改写为 $\mathcal{L}_{\mathcal{H}} = \{(x,y) \mapsto \mathbb{I}\{h(x) \neq y\} : h \in \mathcal{H}\}$。新函数以输入标签对为自变量，以 0 或 1 为输出。

**定理 6.5　图维与一致收敛**　设 $(X, \mathcal{X})$ 为可测空间，$Y$ 为取离散 $\sigma$ 代数的非空标签空间，$\mathcal{H} \subseteq Y^X$ 是由可测分类器组成的非空集合，并令

$$\mathcal{L}_{\mathcal{H}} = \{(x,y) \mapsto \mathbb{I}\{h(x) \neq y\} : h \in \mathcal{H}\}.$$

则 $\mathrm{VC}(\mathcal{L}_{\mathcal{H}}) = d_G(\mathcal{H})$。进一步假定 $\mathcal{L}_{\mathcal{H}}$ 中的函数均可测，且存在可数子类 $\mathcal{L}_0 \subseteq \mathcal{L}_{\mathcal{H}}$，使每个损失函数都是 $\mathcal{L}_0$ 中某个函数序列的逐点极限。此时 $d_G(\mathcal{H}) < \infty$ 当且仅当：对任意 $\eta, \delta \in (0,1)$，存在不依赖联合分布 $\mathcal{P}$ 的样本量 $m(\eta,\delta)$，使任意 $n \geq m(\eta,\delta)$ 及 $S = ((x_i,y_i))_{i=1}^n \sim \mathcal{P}^n$ 均满足

$$\mathbb{P}_{S\sim\mathcal{P}^n}\left\{\sup_{h\in\mathcal{H}} |R_{\mathcal{P}}(h) - \hat{R}_S(h)| \leq \eta\right\} \geq 1-\delta,$$

其中 $R_{\mathcal{P}}$ 与 $\hat{R}_S$ 均为零一损失风险。

**证明**　若以 $f$ 图打散 $C$，在 $\{(x, f(x)) : x \in C\}$ 上，匹配/不匹配使损失实现全部二元赋值，故 $\mathrm{VC}(\mathcal{L}_{\mathcal{H}}) \geq d_G$。

反过来，损失打散的点集不能含同一 $x$ 配两种 $y$，因为两处损失不可能同时为 0。输入于是互异，置 $f(x_i) = y_i$，损失 0/1 便表示匹配/偏离，各模式使这些输入图打散。两维相等后，前章二值函数类的 VC/UC 刻画即给出所述等价。 ■

图维现在判定全类风险是否可共同估准。共同事件也覆盖 ERM 所选输出，便可将经验最优转换为接近类内最低总体风险。下面列出这一推论，并核对两次偏差的来源。

**定理 6.6　一致收敛推出可学习性**　设 $(X, \mathcal{X})$ 为可测空间，$Y$ 为离散标签空间，$\mathcal{H} \subseteq Y^X$ 是由可测分类器组成的非空集合。采用零一损失，记

$$R_{\mathcal{P}}(h) = \mathbb{P}_{(x,y)\sim\mathcal{P}}\{h(x) \neq y\}, \qquad \hat{R}_S(h) = \frac{1}{n}\sum_{i=1}^{n} \mathbb{I}\{h(x_i) \neq y_i\}.$$

假定损失类中的函数均可测，并存在可数损失子类，使每个损失函数都是该子类中某个函数序列的逐点极限；$\mathcal{H}$ 满足分布无关的一致收敛。对任意 $\varepsilon, \delta \in (0,1)$，若 $n \geq 1$ 足以使任意 $X \times Y$ 上的联合分布 $\mathcal{P}$ 及样本 $S \sim \mathcal{P}^n$ 满足

$$\mathbb{P}\left\{ \sup_{h \in \mathcal{H}} |\hat{R}_S(h) - R_{\mathcal{P}}(h)| \leq \varepsilon/2 \right\} \geq 1 - \delta,$$

则任意以概率 1 输出 $A(S) \in \arg\min_{h \in \mathcal{H}} \hat{R}_S(h)$ 的可测 ERM 学习算法 $A$，均以至少 $1 - \delta$ 的概率满足

$$R_{\mathcal{P}}(A(S)) \leq \inf_{h \in \mathcal{H}} R_{\mathcal{P}}(h) + \varepsilon.$$

概率同时来自 $S \sim \mathcal{P}^n$ 和 $A$ 的内部随机性。因此，$\mathcal{H}$ 不可知 PAC 可学习，也可实现 PAC 可学习。

**证明** 将每个 $h$ 换成二值损失函数，经验最优比较保持不变。第 5章的两次 $\varepsilon/2$ 偏差分别用于输出和任意参照，得到总体超额至多 $\varepsilon$；再对参照取下确界即为不可知 PAC。可实现来源使该下确界为 0，因而也满足可实现保证。 ■

图维有限经 UC 再经 ERM，足以推出学习；无限标签下，它却不再是学习存在的必要条件。

UC 约束整个空间，学习器可能只需要辨明正确目标。下面让标签本身透露目标信息，展示全类不 UC 却有成功算法的情形。

这个标签传信息的构造取 $X = \mathbb{N}$，用每个有限自然数子集作一个类别，再设与它们均不同的 $\star$ 表示输入在目标集合外。对有限 $A$ 定义

$$h_A(x) = \begin{cases} A, & x \in A, \\ \star, & x \notin A, \end{cases} \qquad \mathcal{H}_C = \{h_A : A \subset \mathbb{N}\text{有限}\}. \tag{6.3}$$

标签 $\{2, 5\}$ 直接列明集合成员，所以在 $\mathcal{H}_C$ 可实现来源下，一次非 $\star$ 观测就能恢复目标；样本全为 $\star$ 时输出 $h_\varnothing$。这里的数学标签故意携带整条规则，与通常的语义类别不同。

**定理 6.7 可学习性不推出一致收敛** 令 $X=\mathbb{N}$，标签空间 $Y$ 由特殊标签 $\star$ 与 $\mathbb{N}$ 的所有有限子集组成，二者均取离散 $\sigma$ 代数。对每个有限 $A\subseteq\mathbb{N}$ 定义

$$h_A(x)=\begin{cases}A, & x\in A,\\ \star, & x\notin A,\end{cases}\qquad \mathcal{H}_C=\{h_A:A\subseteq\mathbb{N}\text{有限}\}.$$

采用独立同分布抽样与零一损失。学习算法在样本出现非 $\star$ 标签 $A$ 时输出 $h_A$，在所有标签均为 $\star$ 时输出 $h_\varnothing$；该算法使 $\mathcal{H}_C$ 可实现 PAC 可学习。另一方面，对大小为 $n$ 且标签全为 $\star$ 的样本，令 $A_S=\{1,\dots,2n\}\setminus\{x_1,\dots,x_n\}$ 并输出 $h_{A_S}$；对其他样本，在 $h_\varnothing$ 及样本中出现的有限集合标签对应的假设之间，按预先固定的顺序选择零一经验风险最小者。这个规则是确定性恰当 ERM，却没有分布无关 PAC 保证。此外，$\mathcal{H}_C$ 满足 $d_N(\mathcal{H}_C)=1$ 及 $d_G(\mathcal{H}_C)=\infty$，因而不满足零一损失的一致收敛。

**证明** 设目标 $h_A$，以 $p=\mathcal{P}_X(A)$ 记其集合概率。见过非 $\star$ 时恢复目标，风险 0；否则输出空集合规则，风险 $p$。若 $p>\varepsilon$，遗漏事件概率 $(1-p)^n\le e^{-n\varepsilon}$，所以 $n\ge\log(1/\delta)/\varepsilon$ 足够。

任意有限 $C$ 以全 $\star$ 为参考都可图打散：要恰在 $B$ 输出 $\star$，取 $A=C\setminus B$。图维因而无限，UC 失败。非 $\star$ 标签却唯一确定 $h_A$；若两点被 Natarajan 打散，固定一处标签对中的非 $\star$ 者就固定整个假设，另一处无法再自由选两标签，矛盾。单点可取两个标签，所以 $d_N=1$。

这个空间仍有有限样本 ERM。若集合标签 $A$ 未在样本出现，$h_A$ 相比 $h_\varnothing$ 不会修正任何错误，却可能把正确的 $\star$ 改错。因此经验最小值可在 $h_\varnothing$ 与样本出现的有限个集合标签对应假设中取得。预先为全部有限集合排一个顺序，即可固定平局选择。

让另一 ERM 在 $n$ 条全 $\star$ 记录时故意选 $h_{A_S}$，其中 $A_S=\{1,\dots,2n\}\setminus\{x_1,\dots,x_n\}$；其他可实现样本从集合标签恢复目标，不可实现样本则按固定顺序取前述有限候选的经验最小者。全 $\star$ 样本上它零经验错，但目标为空、输入均匀于 $\{1,\dots,2n\}$ 时，至少 $n$ 个未见输入被误判，风险至少 $1/2$。任意 $n$ 都有这样的来源，这个 ERM 不能分布无关 PAC 学习。 ■

好坏两算法在可实现样本上都达到零经验风险，区别在于怎样使用标签信息。这里“有成功学习器”不能由“所有 ERM 都成功”代替[2]。第 6.2.4节的空间完全没有 PAC 学习器，这个空间则只是某些经验最优选择失败，两例承担不同边界。

[2] A. Daniely, S. Sabato, S. Ben-David, S. Shalev-Shwartz, *Multiclass Learnability and the ERM Principle* In Journal of Machine Learning Research, 2015, vol. 16, no. 72, pp. 2377–2404

### 6.3.2 DS 维与可学习性

集合标签例说明图维无限仍可学习，另一例的 Natarajan 维虽有限，却没有 PAC 学习器。所需充要结构应比固定标签对宽，又不要求全类风险估准。六预测例的线索是：即使知道其他输入的答案，遗漏位置也可能仍有竞争标签。

为了描述遗漏坐标上的竞争答案，我们在限制类中寻找有限非空的预测集合 $V \subseteq Y^m$。要求每个 $v \in V$ 在每个坐标 $i$ 上都有集合内的另一个向量 $u$：它只改变该坐标的答案，其余全部坐标与 $v$ 相同。这正是本章下界证明需要的**伪立方体**（pseudo-cube）条件（可参考第一卷“计数与计算”章的伪立方体定义）。

六种预测给二维伪立方体，全部二元 $2^m$ 预测给 $m$ 维伪立方体。多类不要求各坐标固定两种标签，却仍要求预测集合有限；无限邻接集的性质可能不同，不能删除这个条件。

DS 维寻找能保留上述逐坐标歧义的最大输入规模。对 $m$ 个互异输入按固定次序组成的 $C$，检查限制类 $\mathcal{H}|_C$ 是否含 $m$ 维伪立方体；满足条件的有限输入规模取上确界，记为 $d_{DS}(\mathcal{H})$（可参考第一卷“计数与计算”章的 DS 维定义）。下面考察它如何决定学习。

图 6.1展示第 6.2.4节的六种预测，两种线型分别表示只改变一个坐标的邻接。每个顶点在两个坐标上均有邻居，所以这个两输入类的 DS 维为 2；环缺少固定两标签对的完整四种组合，所以 Natarajan 维仅 1。这个有限类仍可学习；无限标签下的不可学习反例还依赖任意维的局部构造及其在同一假设空间中的合并。

在 $m-1$ 个坐标已知时，剩余邻居使遗漏标签未定。对每个向量、每个坐标都要求邻居，避免仅在个别向量周围留少量分支。固定标签对、固定参考答案与逐坐标邻接因而是不同要求；图中的一段邻接关系只有扩展到有限集合内的每个向量和每个坐标，才满足完整伪立方体条件（可参考第一卷“计数与计算”章的“多值函数族的容量”部分）。

这些结构满足 $d_N(\mathcal{H}) \le d_{DS}(\mathcal{H}) \le d_G(\mathcal{H})$；二标签时三者均等于 VC 维。有限标签空间下，Natarajan 维有限还蕴含图维有限（可参考第一卷“计数与计算”章的多分类维度比较定理）。这里使用三个关系：固定标签对的全部组合构成伪立方体；逐坐标邻接支持图打散；有限标签的指数图模式又受多项式预测计数限制。

有限标签的更精细界为 $d_G = O(d_N \log K)$，不能外推无限 $Y$。第 6.2.4节的不可学习反例有 $d_N = 1, d_{DS} = \infty$，故第一道维度差可以无穷。集合标签类 $\mathcal{H}_C$ 则有 $d_{DS} = 1$：出现非 $\star$ 的向量唯一确定假设，不能在别的坐标留邻居，全 $\star$ 独自也不是伪立方体。结合单点可打散得维度 1，而图维无限，故第二道也不能反向替换。

任意坐标都留竞争答案，使未见位置无法由其他标签唯一确定。若任意大的有限输入集都具有这项结构，就能为每个样本量构造学习失败的概率下界。

**定理 6.8　无限 DS 维的不可学习性**　设 $(X, \mathcal{X})$ 为可测空间，$Y$ 为离散标签空间，$\mathcal{H} \subseteq Y^X$ 是由可测分类器组成的非空集合，并采用零一损失。若 $d_{DS}(\mathcal{H}) = \infty$，则对每个整数 $n \geq 1$ 及任意可测学习算法 $A$（允许内部随机性，并允许输出 $\mathcal{H}$ 之外的可测分类器），都存在 $X \times Y$ 上的联合分布 $\mathcal{P}$ 及 $h^\star \in \mathcal{H}$，使 $R_{\mathcal{P}}(h^\star) = 0$，且对 $S \sim \mathcal{P}^n$ 有

$$\mathbb{P}_{S,A}\{R_{\mathcal{P}}(A(S)) > 1/8\} \geq 1/7.$$

这里 $R_{\mathcal{P}}$ 为零一损失期望风险，概率同时来自样本抽取和 $A$ 的内部随机性。

**证明**　取 $2n$ 个 DS 打散点及其有限伪立方体 $V$，输入均匀，从 $V$ 均匀选目标，并为每向量固定一个实现假设。未见坐标即使给其余全标签仍有至少两个等可能答案，平均错误至少 $1/2$。至少一半点未见，总平均风险便至少 $1/4$。选择达到平均下界的固定目标，再用 $\mathbb{E}R \leq 1/8 + (7/8)\mathbb{P}\{R > 1/8\}$，得到所列失败概率。 ■

有限 DS 的充分性要构造学习器，不能要求全空间 UC。Brukhim 等先重构有限标签列表，再从列表得到单标签预测，两步合为压缩[3]。下面先明确借用的构造，再推导它的风险保证。

列表预测 $\mu$ 在每个 $x$ 返回有限集合 $\mu(x) \subseteq Y$，例如保留 {正常, 广告} 两个答案。它覆盖样本意味着每个真实标签都在当地列表中，尚未完成单标签分类。第二步据列表重构一个全样本一致的单标签规则。

**引理 6.9　有限 DS 维的压缩构造**　设 $X, Y$ 为非空集合，$\mathcal{H} \subseteq Y^X$ 非空，且 $d = d_{DS}(\mathcal{H}) < \infty$。存在通用常数 $C > 0$，使得对每个整数 $n \geq 1$，以及每份大小 $q \leq n$、可由某个 $h \in \mathcal{H}$ 正确分类的带标签样本 $S = ((x_i, y_i))_{i=1}^{q}$，均存在如下压缩表示：从 $S$ 中选取一个允许重复、保留次序的带标签序列，长度至多

$$r_n = \min\left\{n, \left\lceil C(d+1)^{3/2} \log^2\!\big(2n(d+1)\big) \right\rceil\right\},$$

并记录原样本大小 $q$。对每个 $q \leq n$，存在不依赖具体样本的固定重构映射，仅根据 $q$ 和该压缩序列输出分类器 $\rho_q : X \to Y$，且 $\rho_q(x_i) = y_i$ 对 $i = 1, \dots, q$ 均成立。重构分类器不要求属于 $\mathcal{H}$。

[3] N. Brukhim, D. Carmon, I. Dinur, S. Moran, A. Yehudayoff, *A Characterization of Multiclass Learnability* In Proceedings of the 63rd Annual Symposium on Foundations of Computer Science, 2022, pp. 943–955

这是原文定理 36 在常数和对数因子上放宽的表述。引理 39 用有限 DS 维重构覆盖原样本的列表，引理 40 用有限 Natarajan 维在列表内重构一致单标签规则；拼接压缩序列即可依次重构，$d_N \le d$ 使第二步也受 $d$ 控制。取 $t = \lceil \sqrt{d+1} \rceil$ 得到所列对数平方长度；上界超过 $n$ 时保存全样本即可。列表部分借用原文的超图定向，本章仅说明该构造怎样进入压缩与风险分析。

接下来限制可能的压缩序列数，再沿第 5章的压缩分析同时控制全部重构结果。计数依赖序列长度，未依赖标签总数，因此无限标签仍可分析。

**定理 6.10　有限 DS 维的期望风险保证**　设 $(X, \mathcal{X})$ 为可测空间，$Y$ 为离散标签空间，$\mathcal{H} \subseteq Y^X$ 是由可测分类器组成的非空集合，$d = d_{DS}(\mathcal{H}) < \infty$，并采用零一损失。存在通用常数 $C > 0$；对每个整数 $n \ge 1$ 令

$$r_n = \min\left\{n, \left\lceil C(d+1)^{3/2} \log^2\!\big(2n(d+1)\big) \right\rceil\right\}.$$

固定满足 $r = r_n < n$ 的 $n$。假定每个候选分类器的零一损失函数，以及所用压缩、重构和有限候选选择映射均可测。预先固定一个 $h_0 \in \mathcal{H}$ 和全部压缩描述的顺序；对每份 $S = ((x_i, y_i))_{i=1}^n$，枚举由原样本大小、至多 $r$ 个允许重复且保留次序的样本索引组成的描述，用固定重构映射产生候选，无效描述统一返回 $h_0$。令 $A^{\mathrm{real}}$ 选择顺序最先且与 $S$ 一致的候选；若不存在则返回 $h_0$。令 $A^{\mathrm{agn}}$ 选择顺序最先且零一经验风险最小的候选。记

$$B_n(\delta) = \log \frac{2(n+1)(r+1)n^r}{\delta}.$$

这两个确定性算法允许输出 $\mathcal{H}$ 之外的可测分类器。对任意 $\delta \in (0,1)$，以下保证成立：

1. 对任意 $X \times Y$ 上的联合分布 $\mathcal{P}$，若存在 $h^\star \in \mathcal{H}$ 满足 $R_{\mathcal{P}}(h^\star) = 0$，则对 $S \sim \mathcal{P}^n$，以至少 $1-\delta$ 的概率，

$$R_{\mathcal{P}}(A^{\mathrm{real}}(S)) \le \frac{B_n(\delta)}{n-r}.$$

2. 对任意 $X \times Y$ 上的联合分布 $\mathcal{P}$ 和 $S \sim \mathcal{P}^n$，以至少 $1-\delta$ 的概率，

$$R_{\mathcal{P}}(A^{\mathrm{agn}}(S)) \le \inf_{h \in \mathcal{H}} R_{\mathcal{P}}(h) + \frac{r}{n} + \sqrt{\frac{B_n(\delta)}{2(n-r)}} + \sqrt{\frac{\log(2/\delta)}{2n}}.$$

其中 $R_{\mathcal{P}}$ 为零一损失期望风险，两项概率都只来自独立同分布样本。

**证明（使用引理 6.9）**　有序序列允许重复，长度至多 $r$ 时至多 $(r+1)n^r$ 种索引；再计 $n+1$ 种原样本大小，描述总数至多 $M=(n+1)(r+1)n^r$。这些索引在看数据前确定，未预先列举无限标签。

先于数据固定 $h_0\in\mathcal{H}$ 和描述顺序。描述包含原样本大小、序列长度与可重复索引；重构补为总映射，无效描述返回 $h_0$，每份样本便有至多 $M$ 个有序候选。可实现算法取首个全一致者，压缩引理保证它存在；不可知算法取首个经验最小者。题设的可测映射使这两种有限选择也可测。

固定索引描述，设实际读取 $j\le r$ 个不同观测。给定这些值后，候选已确定，其余 $n-j$ 个观测仍 iid。风险大于 $u$ 的候选全分对余下者的概率至多 $(1-u)^{n-j}\le e^{-(n-r)u}$。对 $M$ 种描述作并集界，就覆盖首个全一致输出；取 $u=B_n(\delta)/(n-r)$ 得到可实现界，$u\ge 1$ 时则用风险不超过 1 的平凡保证。

不可知算法在有限重构结果中选首个经验最小者。对固定描述，以 $\hat{R}_{\mathrm{rest}}$ 记未读取观测的损失平均。条件独立性与单侧 Hoeffding，再跨 $M$ 个描述求和，使下式以至少 $1-\delta/2$ 的概率同时成立：

$$R_{\mathcal{P}}(h)\le \hat{R}_{\mathrm{rest}}(h)+\sqrt{\frac{\log(2M/\delta)}{2(n-r)}}.$$

删去 $j$ 条观测后平均损失最多增加 $j/n$。把全样本均值写成剩余与已读两部分的加权平均，就得 $\hat{R}_{\mathrm{rest}}(h)\le \hat{R}_S(h)+j/n\le \hat{R}_S(h)+r/n$，可以代入上式。

任意预先固定 $g\in\mathcal{H}$，把它分对的样本组成可实现子样本，压缩引理提供在这些观测上全对的重构者；其经验风险至多 $\hat{R}_S(g)$。子样本为空时，$\hat{R}_S(g)=1$，任意候选都不更大。经验最小重构于是满足 $\hat{R}_S(A^{\mathrm{agn}}(S))\le \hat{R}_S(g)$。对固定 $g$ 再用 Hoeffding，以至少 $1-\delta/2$ 的概率有

$$\hat{R}_S(g)\le R_{\mathcal{P}}(g)+\sqrt{\frac{\log(2/\delta)}{2n}}.$$

合并两个半失败预算即得到相对该 $g$ 的风险界。任取正的 $\tau$，在抽样前选风险距类内下确界不足 $\tau$ 的 $g$，得到超过所列上界加 $\tau$ 的概率至多 $\delta$；令 $\tau\downarrow 0$，由事件单调收敛得到第二结论，无需所有参照同时估准。 ■

固定 $d$ 时 $r_n=O(\log^2 n)$，所以 $r_n/n\to 0$，两种风险界分别趋于零与类内最优基准。略去 $n,d$ 的对数因子，可实现风险为 $\widetilde{O}((d^{3/2}+\log(1/\delta))/n)$，不可知超额为 $\widetilde{O}(\sqrt{(d^{3/2}+\log(1/\delta))/n})$。这些量说明统计保证，没有保证压缩搜索可计算或多项式时间完成。

无限 DS 的必要性与有限 DS 的构造合起来，得到多类基本定理。前章 VC 统一描述的性质现在分为图维和 DS 维两组；有限标签时，两组有限性再度等价，一般 $Y$ 时则须区分。

**定理 6.11　多分类学习基本定理**　设 $(X, \mathcal{X})$ 为可测空间，$Y$ 为取离散 $\sigma$ 代数的非空标签空间，$\mathcal{H} \subseteq Y^X$ 是由可测分类器组成的非空集合，并采用零一损失。假定

$$\mathcal{L}_{\mathcal{H}} = \{(x, y) \mapsto \mathbb{I}\{h(x) \neq y\} : h \in \mathcal{H}\}$$

中的函数均可测，且存在可数子类 $\mathcal{L}_0 \subseteq \mathcal{L}_{\mathcal{H}}$，使每个损失函数都是 $\mathcal{L}_0$ 中某个函数序列的逐点极限。假定有限 DS 压缩构造中的压缩、重构和有限候选选择映射均可测。学习算法均为可测映射，允许输出 $\mathcal{H}$ 之外的可测预测器；训练样本均为 $S \sim \mathcal{P}^n$，成功概率同时计入样本抽取和算法的内部随机性。在这一分布无关设定中，以下命题等价：

1. $d_{DS}(\mathcal{H}) < \infty$；
2. $\mathcal{H}$ 可实现 PAC 可学习；
3. $\mathcal{H}$ 不可知 PAC 可学习。

此外，$d_G(\mathcal{H}) < \infty$ 当且仅当零一损失满足分布无关的一致收敛；有限图维或一致收敛中的任一条件均蕴含前三条，但一般不存在反向蕴含。

**证明（使用有限 DS 维的学习器构造结果）**　DS 有限时，当样本量足够大，定理 6.10的两项风险界可分别满足任意给定的误差容限和失败概率要求，因而给出两种分布无关 PAC 保证。不可知包含可实现，而无限 DS 已排可实现，故三项等价。图维/UC 等价见定理 6.5，学习不推 UC 由定理 6.7的集合标签例证明。充分性仍依赖已引用的外部学习构造。 ■

一般多类有两项刻画：图维有限等价于零一 UC，DS 维有限等价于 PAC 学习器存在。前者推后者，逆向失败。有限标签使 $d_N, d_{DS}, d_G$ 有限性、UC 及两种 PAC 全部等价；二类时三维都回到 VC。有限标签的学习等价见定理 6.2（维度关系可参考第一卷“计数与计算”章的多分类维度比较定理）。

定性维度有限没有确定最优样本量或高效实现，不能在二类样本式中只换 VC 为 DS 便得新公式。

## 6.4 可计算 PAC 学习

### 6.4.1 统计保证与程序实现

沿用第 5.7节的三层区别：统计学习、训练预测总停机、多项式资源。现在标签程序返回 $Y$ 中的值，仍须停机，风险成功标准保持前述 PAC 要求。

取 $X=\mathbb{N}$，沿用定义 5.17的程序要求，但须先给标签和假设有效表示：标签编码可计算、相等可判定，有限标签全集可枚举，允许假设及输出由预定可递归枚举表示提供。不可知学习器对每份有限样本停机，返回一个对每输入停机输出 $Y$ 标签的程序，并对所有允许来源和所有足量 $n$ 满足

$$\mathbb{P}_{S\sim\mathcal{P}^n}\left\{R_{\mathcal{P}}(A(S))\le \inf_{h\in\mathcal{H}} R_{\mathcal{P}}(h)+\varepsilon\right\}\ge 1-\delta$$

。输出在 $\mathcal{H}$ 内是恰当，允许其他可计算规则是非恰当。再要求可计算充分样本上界得到 strong CPAC，与前章同义，未要求多项式时间。

**定理 6.12　多分类可计算 ERM 的充分条件**　在离散输入空间 $X=\mathbb{N}$ 和具有可计算编码、可判定相等关系的非空标签空间 $Y$ 上采用零一损失。设非空假设空间 $\mathcal{H}\subseteq Y^X$ 采用固定有效表示，并存在确定性程序 $A$：它对每份有限样本 $S=((x_i,y_i))_{i=1}^n$ 都停机，输出 $A(S)\in\mathcal{H}$ 的程序编码；该输出程序对每个 $x\in\mathbb{N}$ 都停机，且

$$\hat{R}_S(A(S))=\min_{h\in\mathcal{H}}\frac{1}{n}\sum_{i=1}^{n}\mathbb{I}\{h(x_i)\neq y_i\}.$$

若 $d_G(\mathcal{H})<\infty$，则存在可计算的样本量上界 $m(\varepsilon,\delta)$，使任意 $\varepsilon,\delta\in(0,1)$、任意 $\mathbb{N}\times Y$ 上的联合分布 $\mathcal{P}$、任意 $n\ge m(\varepsilon,\delta)$ 及 $S\sim\mathcal{P}^n$ 均满足

$$\mathbb{P}_{S\sim\mathcal{P}^n}\left\{R_{\mathcal{P}}(A(S))\le \inf_{h\in\mathcal{H}} R_{\mathcal{P}}(h)+\varepsilon\right\}\ge 1-\delta.$$

因此，$\mathcal{H}$ 恰当地不可知 CPAC 可学习，且有可计算的样本量上界；概率仅来自独立同分布样本。若 $2\le|Y|<\infty$ 且标签全集可有效枚举，则条件 $d_N(\mathcal{H})<\infty$ 可以替代 $d_G(\mathcal{H})<\infty$。

**证明**　定理 6.5将图维等同于损失 VC 维，因此给出显式 UC 样本界。取偏差 $\varepsilon/2$，两次比较使 ERM 超额至多 $\varepsilon$；训练和预测停机来自题设。固定空间的有限维上界可写入样本量程序。有限标签时，Natarajan 维有限蕴含图维有限，所以可替条件（可参考第一卷“计数与计算”章的多分类维度比较定理）。 ■

这条充分路线与前章可计算 ERM 对应：二类用 VC，多类用零一损失的图维，有限标签又可用 Natarajan。维度有限若没有训练与预测程序，不能仅凭统计定理声称可计算。

### 6.4.2 可计算 Natarajan 维

Natarajan 有限保证足量输入的固定标签对中有一种二元预测缺失；程序却需要实际找出它。**可计算 Natarajan 维**（computable Natarajan dimension）在这一组合存在性上增加总可执行的见证。

**定义 6.13 可计算 Natarajan 维** 若存在总可计算程序 $W$，对任意 $d+1$ 个互异输入 $x_i$ 及标签对 $(a_i, b_i)$、$a_i \neq b_i$，都输出 $s \in \{0,1\}^{d+1}$，使得

$$\nexists h \in \mathcal{H} \quad \forall i : \; h(x_i) = \begin{cases} a_i, & s_i = 0, \\ b_i, & s_i = 1, \end{cases}$$

则称 $d$ 为可计算 Natarajan 维的一个上界。最小的这种非负整数记为 $c_N(\mathcal{H})$；不存在时记为 $\infty$。

普通维度保证缺失存在，可计算维度要求同一程序根据输入与标签对返回缺失者。因此 $d_N \leq c_N$；二类时该见证就是前章的有效 VC 见证。

充分性借用 Gourdeau 等的有效扩展：有限标签且 $c_N(\mathcal{H}) = d$ 时，可构造包含 $\mathcal{H}$ 的 $\mathcal{H}'$，使 $d_N(\mathcal{H}') \leq d+1$，并能有效求出有限输入上的全部可实现预测及实现假设[4]。下面把该外部构造与后续风险推导分开。

**定理 6.14 有限标签的非恰当 CPAC 刻画** 设 $X = \mathbb{N}$、$2 \leq |Y| < \infty$，二者取离散 $\sigma$ 代数，并采用零一损失。假定标签具有可计算编码、可判定的相等关系，且标签全集可有效枚举；非空假设空间 $\mathcal{H} \subseteq Y^X$ 及允许的输出程序采用预先规定的可递归枚举表示。把 $c_N(\mathcal{H})$ 定义为满足以下条件的最小非负整数 $d$：存在总可计算程序 $W$，对任意 $d+1$ 个互异输入 $x_i$ 及任意标签对 $(a_i, b_i)$、$a_i \neq b_i$，输出 $s \in \{0,1\}^{d+1}$，使不存在 $h \in \mathcal{H}$ 同时满足

$$h(x_i) = \begin{cases} a_i, & s_i = 0, \\ b_i, & s_i = 1 \end{cases} \qquad (i = 1, \ldots, d+1);$$

若不存在这样的 $d$，则令 $c_N(\mathcal{H}) = \infty$。学习器取确定性程序，对每份有限样本都停机，并可输出有效构造的可递归枚举扩展类中的总可计算假设；PAC 成功概率仅来自 $S \sim \mathcal{P}^n$。在这一表示模型中，$\mathcal{H}$ 非恰当地不可知 CPAC 可学习，当且仅当 $c_N(\mathcal{H}) < \infty$。

[4] P. Gourdeau, T. Lechner, R. Urner, *On the Computability of Multiclass PAC Learning* In arXiv preprint arXiv:2502.06089, 2025

**证明（充分性使用有效扩展引理）**　必要性使用有效的未见输入论证。设 CPAC 程序 $A$ 存在，固定使精度与失败概率均为 $1/16$ 的保证成立的样本量 $n$。给 $2n$ 个输入及各两标签，有限枚举二元目标，再对每目标枚举这组输入上全部长度 $n$ 的有序样本，训练并计算输出在 $2n$ 点的错误比例。全部训练与预测都停机，有限平均因而可计算。

未见输入的随机二元目标分析给出至少一个候选的平均风险不低于 $1/4$；有限枚举可找出它并返回选择向量。若它由 $\mathcal{H}$ 实现，双容限 $1/16$ 的 PAC 保证反使均值至多 $1/16+1/16<1/4$，矛盾，故它是缺失预测。见证规模为 $2n$，得到 $c_N \le 2n-1$。$n$ 针对该空间固定写入程序，未要求从任意学习器描述自动算出。

充分性在外部扩展 $\mathcal{H}'$ 上运行：枚举有限样本的可实现预测，选错误最少者并返回其可计算实现，构成可计算 ERM。有限标签及 $d_N(\mathcal{H}')$ 有限给不可知 PAC；又因 $\mathcal{H}\subseteq\mathcal{H}'$，扩展类风险下确界不大于原类，所以同一输出也满足原类超额要求。输出可能在 $\mathcal{H}$ 外，故为非恰当学习。 ■

这里选确定性学习程序，成功概率只含样本。若模型加入随机位，须规定它们的使用，不能直接枚举所有随机运行。必要性与充分性还依赖允许假设和输出程序的有效表示；仅要求输出某个总可计算函数而不定表示，不属于本章刻画范围。

必要方向没有用标签有限，因此相同有效表示模型的无限标签 CPAC 也须 $c_N<\infty$。充分方向的有效扩展依赖有限标签预测枚举，不能沿用到无限 $Y$。前述统计反例只算出有限 $d_N$，没有算 $c_N$，故它不足以判定无限标签的有限 $c_N$ 是否充分，该问题需要另一项定理。

DS 有限不自动给伪立方体搜索、列表构造与单标签归约的执行程序，所以统计刻画不能直接命名为 CPAC。具体空间仍可走另一充分路线：构造可计算 ERM，再证零一 UC；有限标签的有限 Natarajan 或任意标签的有限图维都能支持后一步。

### 6.4.3 高效学习与优化误差

停机之外还要给样本、训练、预测及输出长度的资源界。多类标签编码也须计费：当 $K\ge 2$ 时，类别编号长约 $\log K$；单标签任务只需固定常量描述，集合等结构标签则按其实际描述长计算。

标签数不影响近似 ERM 的三次比较。若输出 $A(S)\in\mathcal{H}$ 且

$$\hat{R}_S(A(S)) \le \inf_{h\in\mathcal{H}} \hat{R}_S(h) + \alpha,$$

全部风险偏差又至多 $\eta$，则

$$R_{\mathcal{P}}(A(S)) \le \inf_{h\in\mathcal{H}} R_{\mathcal{P}}(h) + 2\eta + \alpha.$$

按定理 5.21，$2\eta$ 来自两次抽样均值替换，$\alpha$ 来自经验目标求解差。若用规模参数的多项式样本使 $\eta \le \varepsilon/4$，以多项式训练时间取得 $\alpha \le \varepsilon/2$，并使输出长和预测时间也为多项式，就得到高效不可知 PAC 的充分路线。

### 6.4.4 从枚举到有效算法

前章合取用结构搜索省去指数枚举，多类也能这样做。取 $X=\{1,\dots,p\}, Y=\{1,\dots,K\}$ 及全部函数 $\mathcal{H}=Y^X$，候选虽有 $K^p$ 个，经验目标却可按输入分别求解。

对每个 $x$ 计 $N_{x,y}=|\{i : x_i=x, y_i=y\}|$，选计数最多的标签，平局取最小编号，未见输入取 1。正确数对 $x$ 可加，不同输入的选择不互相约束，故逐行最优就是全表经验最优。

**定理 6.15　有限输入上的多分类表学习**　设 $p,K,n\ge 1$，$X=\{1,\dots,p\}$、$Y=\{1,\dots,K\}$ 均取离散 $\sigma$ 代数，$\mathcal{H}=Y^X$，并采用零一损失。令 $\mathcal{P}$ 为 $X\times Y$ 上的任意联合分布，$S=((x_i,y_i))_{i=1}^n\sim\mathcal{P}^n$。确定性学习算法对每个 $x\in X, y\in Y$ 计算 $N_{x,y}=|\{i : x_i=x,\ y_i=y\}|$，在每个 $x$ 处选择计数最大的标签，平局时选择编号最小者，未出现的输入预测为 1。该算法是 $Y^X$ 上的恰当 ERM，需要 $O(n+pK)$ 次计数和比较操作，输出一张含 $p$ 个标签的预测表。对任意 $\varepsilon,\delta\in(0,1)$，若

$$n \ge \frac{2}{\varepsilon^2}\left(p\log K + \log\frac{2}{\delta}\right),$$

则以关于 $S\sim\mathcal{P}^n$ 至少 $1-\delta$ 的概率，其零一损失期望风险不超过 $\inf_{h\in\mathcal{H}} R_{\mathcal{P}}(h)+\varepsilon$。

**证明**　$h$ 分对样本数为 $\sum_{x=1}^{p} N_{x,h(x)}$，逐行选最大计数即使总和最大，也就使经验风险最小。初始化 $pK$ 计数器、扫描 $n$ 观测、再逐行比较，操作数为 $O(n+pK)$。有限类大小 $K^p$ 与 Hoeffding 并集使偏差超过 $\varepsilon/2$ 的概率至多 $2K^p e^{-n\varepsilon^2/2}$，令其至多 $\delta$ 再用 ERM 两次比较，得到风险保证。 ■

操作按 $p,K$ 计费，计数器至多 $O(\log(n+1))$ 位，所以比特时间也为这些参数的多项式。若巨大 $K$ 只由短程序表示，$O(K)$ 却不等于其描述长的多项式。当 $K\ge 2$ 时，输出表长 $O(p\log K)$ 也进入资源预算；$K=1$ 时，一张含 $p$ 个固定标签的表可用 $O(p)$ 位表示，也可用常量规则表示。

## 6.5 本章小结

多类让同一输入拥有多个替代答案，改变了前章的容量刻画。编码归约仍须分析子类复杂度、位错累积、无效码解法及非恰当输出。在有限标签下，Natarajan 限制预测数，计数、对称化和 ERM 比较因而沿用；在本章可测条件下，其有限性、分布无关 PAC 与 UC 等价。

无限标签分开全类估计与算法存在。图维是零一损失类 VC 维，判定共同风险估计；DS 维判定统计学习，学习器无须全类估准。Natarajan 有限只保留必要性。图维有限足以学习，学习却不推出它有限，这解释了二类等价不能原样外推。

经验最小值相同，选择规则仍可能使泛化不同，ERM 目标本身没有说明全部学习行为。训练与预测要求总停机后，还需有效组合见证；有限标签的可计算 Natarajan 提供刻画，却未给多项式时间。下一章换为一般损失，并用稳定性继续考察 UC 之外的保证。

**延伸阅读**　Daniely 等的研究可用于对照成功学习器存在与任意 ERM 成功，特别核对多个经验最优解的选择怎样改变样本量，以及图维在其中的作用[5]。

Brukhim 等建立 DS 学习刻画。本章将列表、压缩与单标签输出连接风险，借用的组合构造则需继续读原文的伪立方体和列表分析；有限标签 Natarajan 证明不能替代这些结果[6]。

Gourdeau、Lechner 与 Urner 的工作提供对应第 5.7节有效 VC 的多类计算视角。阅读时须核标签编码、输出求值以及恰当/非恰当范围，才能判断同一统计空间的实现要求[7]。

[5] A. Daniely, S. Sabato, S. Ben-David, S. Shalev-Shwartz, *Multiclass Learnability and the ERM Principle* In Journal of Machine Learning Research, 2015, vol. 16, no. 72, pp. 2377–2404

[6] N. Brukhim, D. Carmon, I. Dinur, S. Moran, A. Yehudayoff, *A Characterization of Multiclass Learnability* In Proceedings of the 63rd Annual Symposium on Foundations of Computer Science, 2022, pp. 943–955

[7] P. Gourdeau, T. Lechner, R. Urner, *On the Computability of Multiclass PAC Learning* In arXiv preprint arXiv:2502.06089, 2025

第 7 章

# 一般学习的可学习性

前两章的分类问题用零一损失记录预测是否正确。若预测的是温度，仅记录“答错”就无法区分偏差为 2 度和 10 度的结果；若要寻找聚类中心，观测中甚至没有供比较的正确标签。这些任务需要各自的损失函数，却都要根据有限样本选择一个结果，再考察它在新观测上的平均损失。我们将预测函数、聚类中心和投影矩阵等选择结果统称为决策。本章要研究：对一般损失和决策空间，哪些条件能保证样本选出的决策接近最低期望风险？

分类理论通过约束整个假设空间回答这一问题。二分类的 VC 维控制候选预测能够形成多少不同模式，多分类的图维则控制带标签样本上的正误组合。相应维度有限时，我们可以同时估计所有假设的风险。然而，一般学习问题中，即使某些决策的经验风险严重低估期望风险，算法也可能始终避开这些决策。要解释这样的学习过程，就需要从“有哪些候选决策”进一步转向“算法如何选择决策”。

选择过程对样本的依赖可以通过**算法稳定性**（algorithmic stability）来考察：我们删除或替换一个观测，比较算法输出在同一观测上的损失变化。如果这种变化受到适当控制，经验评价与总体评价之间的差便可受到控制；再要求算法把经验风险降到接近最优，才得到学习保证。一致收敛和稳定性因此提供两条分析路径。后面的正则化与随机梯度下降分析将说明如何验证这些条件，以及凸性、参数约束和优化过程分别在哪一步发挥作用。

## 7.1 一般学习问题

为在同一框架内评价不同任务，我们沿用第 4.1节的设定：观测属于 $Z$，允许的分布组成 $\mathfrak{P}$，样本 $S = (z_1, \dots, z_n)$ 独立取自某个 $\mathcal{P} \in \mathfrak{P}$。损失 $\ell(w, z)$ 评价决策 $w$ 在观测 $z$ 上的结果。算法结合样本与内部随机数 $U$，输出 $A(S, U) \in \mathcal{W}_{\text{out}}$；评价时则与比较空间 $\mathcal{W}$ 中的最低期望风险相比较。期望风险、经验风险及 PAC 保证中的量词，分别采用定义 4.2–4.4。

从分类转向这些任务时，改变的是损失的取值和决策的形式。我们不再只计数分类模式，而要分析损失函数空间的复杂度，或分析算法的稳定性

与经验优化误差。有界性、凸性、光滑性和矩条件将在需要它们的定理中分别列明。

### 7.1.1 观测、决策与损失

我们先看损失为何需要随任务改变。真实温度为 20 时，预测 18 和 10 都答错了，但平方损失分别为 4 和 100，能够区分偏差大小。聚类没有给定正确标签，可以改为计算数据点到最近中心的距离。因此，一般学习保留用样本选择决策的过程，同时允许用不同损失评价选择结果。

在上述温度例子中，观测必须同时包含输入和真实温度，才能计算预测误差。一般地，$z$ 包含评价所需的信息，$w$ 表示待评价的选择，可以是预测函数、聚类中心或投影矩阵。损失 $\ell(w,z)$ 越小，表示该决策在当前评价标准下越好。按定义 4.2与定义 4.3分别对总体和样本取平均后，我们比较算法结果与 $\inf_{w\in\mathcal{W}} R_{\mathcal{P}}(w)$ 之间的差。

二分类和回归都可以观察 $z=(x,y)$，并以预测函数为决策。两者的区别落在损失上：二分类比较预测类别与标签是否一致，回归可以用 $(w(x)-y)^2$ 记录数值误差。无论采用哪种损失，训练依赖有限样本，使用时面对新的观测。

没有标签的任务也可沿用这一评价方式。$K$ 均值只观察输入 $x$，选择中心 $w=(c_1,\dots,c_K)$，再用 $\min_j \|x-c_j\|_2^2$ 评价它。例如，$x=2$ 到中心 0 和 5 的平方距离为 4 和 9，取较小值后损失为 4。训练寻找样本平均距离较小的中心，期望风险则评价新数据到这些中心的平均距离。PCA 选择的是秩为 $r$ 的正交投影 $P$，以 $\|x-Px\|_2^2$ 评价无法重构的部分。

统一的风险形式让我们能够比较学习条件，却没有消除各任务的优化差异。$K$ 均值对全部中心的联合优化一般并不凸，因而不能直接使用后面的凸学习定理。同样，期望风险较低只说明所选损失较小，不保证恢复唯一的“真实聚类”或“真实子空间”。应用定理时，仍须检查具体损失和决策空间是否满足其条件。

### 7.1.2 可学习性的目标

这里所说的“学会”，是达到定义 4.4中的不可知目标：算法的期望风险接近比较空间中的最低值，不要求最低值为零。一般任务也未必存在需要恢复的标签函数，目标由观测分布、比较空间和损失共同规定。除非另行说明，本章令 $\mathcal{W}_{\text{out}}=\mathcal{W}$，要求算法输出属于比较空间，即采用恰当输出。

这一目标同时约束决策、损失与数据来源。固定同一组预测函数，有界输入下的平方损失保证，并不自动适用于任意重尾输入。限制参数会缩小决策空间，改用替代损失会改变评价标准，限制分布族会缩小保证覆盖的

数据来源。我们每次作出这些改变，都要重新说明学习问题保留了哪些条件。

下面关于维度刻画和必要条件的讨论采用有界损失。正则化与 SGD 的分析则根据各自推导，另外要求凸性、Lipschitz 性或可积性。尤其是平方损失，必须连同输入和参数的约束一起检查，不能把有界区域内的结论扩展到无约束的重尾回归。

## 7.2 一致收敛

从零一损失换成平方损失后，我们仍要估计每个决策的期望风险，但函数取值已不再只有 0 和 1。为此，应把每个决策对应的损失函数放在一起，得到

$$\mathcal{F}_\ell = \{z \mapsto \ell(w, z) : w \in \mathcal{W}\},$$

再控制这组函数的样本平均与总体平均之差。这里选择损失函数空间，是因为风险直接平均损失；同一组预测函数配上不同损失，可能得到有界性和复杂度不同的函数空间。预测函数本身的维度因而不能未经转换就代入风险界。

这里仍要求一份样本同时估准整个损失类：对任意 $\eta, \delta \in (0,1)$，一个充分门槛 $n_{\mathrm{uc}}(\eta, \delta)$ 应使每个允许分布 $\mathcal{P}$ 及每个 $n \ge n_{\mathrm{uc}}(\eta, \delta)$ 满足

$$\mathbb{P}_{S\sim\mathcal{P}^n}\left\{\sup_{w\in\mathcal{W}} |\hat{R}_S(w) - R_{\mathcal{P}}(w)| \le \eta\right\} \ge 1 - \delta.$$

这是一般损失类上的一致收敛要求（可参考第一卷“随机变量”章的一致收敛定义）。这里的样本门槛可以随决策空间、损失、精度和置信度改变，却必须同时适用于每个允许分布。上确界则要求样本对所有决策的风险估计都达到精度。实值函数有连续取值，要检验这样的保证，我们需要将前章的打散扩展为函数值与阈值的比较。

### 7.2.1 伪维与胖打散维

比较实值函数时，我们可以在各输入处设置阈值，记录函数值位于阈值的哪一侧。伪维计数能够实现的这类二元模式；胖打散维 $\mathrm{fat}_\gamma(\mathcal{F})$ 进一步要求两侧函数值与阈值至少相隔 $\gamma$，从而记录指定数值精度下的区分能力（可参考第一卷“计数与计算”章的伪打散定义、同章的伪维定义与同章的胖打散维定义）。二值函数的伪维等于 VC 维；多分类标签若只是名称，任意编号会引入人为的大小关系，因此这种编号后的伪维不能替代多分类维度。

阈值比较与带间隔比较的差别，可以用一个幅度逐渐衰减的函数类说明。令 $X = \mathbb{N}$，每个有限集 $C \subset \mathbb{N}$ 对应 $f_C(i) = 1/i$（$i \in C$）和 $f_C(i) = 0$

($i \notin C$)。任取有限多个点 $i_1, \dots, i_m$，将阈值设为 $r_j = 1/(2i_j)$，再通过选择 $C$ 决定哪些点位于阈值上方，就能实现全部高低模式，故伪维无限。胖打散却要求每个点的两个可选值相差至少 $2\gamma$。由于这里的差只能是 $1/i$，被胖打散的点必须满足 $i \le 1/(2\gamma)$，所以每个正尺度的胖打散维都有限。接下来要检验的是：哪一种区分能力能够控制风险估计的统一偏差？

### 7.2.2 一致收敛与期望风险

风险估计只要求达到指定精度，因而相关的容量也应在这个数值尺度上衡量。下面的定理表明：对 $[0,1]$ 值函数，若允许全部概率分布，一致收敛等价于每个正尺度的胖打散维有限。一般有界区间可先平移缩放到这一范围。若只允许较小分布族 $\mathfrak{P}$，有限胖打散维仍足以保证一致收敛，但反向结论可能失败，因为受限分布未必能显露全部函数差异。无界损失还需尾部控制。这里及下文假定涉及的上确界、算法和期望满足所需可测性条件。

**定理 7.1　胖打散维与一致收敛**　设 $(X, \mathcal{A})$ 为可测空间，$\mathcal{F}$ 为非空的 $[0,1]$ 值可测函数空间。假定存在可数子空间 $\mathcal{F}_0 \subseteq \mathcal{F}$，使每个 $f \in \mathcal{F}$ 都是 $\mathcal{F}_0$ 中某个函数序列的逐点极限。则以下两个命题等价：

1. 对每个 $\gamma > 0$，$\mathrm{fat}_\gamma(\mathcal{F}) < \infty$。
2. 对任意 $\eta, \delta \in (0,1)$，存在整数 $n_0 = n_0(\mathcal{F}, \eta, \delta)$，使任意 $X$ 上的概率分布 $\mathcal{P}$ 和任意 $n \ge n_0$ 均满足

$$\mathbb{P}_{(x_1,\dots,x_n)\sim\mathcal{P}^n}\left\{\sup_{f\in\mathcal{F}}\left|\frac{1}{n}\sum_{i=1}^{n} f(x_i) - \mathbb{E}_{x\sim\mathcal{P}} f(x)\right| > \eta\right\} \le \delta.$$

两条等价条件有各自的量词。维度条件要求每个 $\gamma > 0$ 对应的维度有限，允许这些维度随 $\gamma$ 减小而增长；收敛条件要求同一个 $n_0$ 适用于所有分布。可数子空间 $\mathcal{F}_0$ 负责处理上确界的可测性，$\mathcal{F}$ 可数时直接取 $\mathcal{F}_0 = \mathcal{F}$。有界性还使逐点逼近带来期望收敛，从而可通过可数子空间处理概率事件。要将定理用于学习，只需把 $X$ 换成观测空间 $Z$、令 $\mathcal{F} = \mathcal{F}_\ell$，并检查这些有界性和可测性条件。

这一等价刻画的经典形式及必要方向见学习理论教材[1]。改进的一致收敛上界见[2]。充分方向沿用副样本论证，但实值函数无法再靠精确计数预测向量处理。我们改为把有限样本上足够接近的损失向量归为一组，用代表向量近似组内函数。胖打散维控制指定精度下需要的代表数；对这些代表应用集中不等式，再加上近似误差，就得到全部函数的偏差控制。必要方向从某个正尺度上任意大的打散集出发，构造统一偏差不能消失的分布。完整证明还需要覆盖数的组合估计，以上仅解释证明路径。

[1] S. Shalev-Shwartz, S. Ben-David, *Understanding Machine Learning: From Theory to Algorithms*, Cambridge University Press, 2014, 1st ed.

[2] R. Colomboni, E. Esposito, A. Paudice, *An Improved Uniform Convergence Bound with Fat-Shattering Dimension* In arXiv preprint arXiv:2307.06644, 2023

由于胖打散必然满足伪打散，有限伪维可以作为一致收敛的充分条件。上面的幅度衰减例子也表明，它并非必要条件。若要直接估计给定样本上的复杂度，还可将第 5章的 Rademacher 复杂度用于损失函数空间，再据此控制期望风险。

**定理 7.2　一致收敛推出一般学习保证**　设 $(Z, \mathcal{Z})$ 为可测观测空间，$(\mathcal{W}, \mathcal{B}_{\mathcal{W}})$ 为非空可测决策空间，$\mathfrak{P}$ 为 $Z$ 上的一族概率分布。设 $\ell : \mathcal{W} \times Z \to \mathbb{R}$ 可测，且对每个 $\mathcal{P} \in \mathfrak{P}$ 和 $w \in \mathcal{W}$ 都有 $\ell(w, \cdot) \in L^1(\mathcal{P})$。对 $S = (z_1, \dots, z_n) \sim \mathcal{P}^n$ 定义

$$R_{\mathcal{P}}(w) = \mathbb{E}_{z \sim \mathcal{P}} \ell(w, z), \qquad \hat{R}_S(w) = \frac{1}{n} \sum_{i=1}^{n} \ell(w, z_i),$$

并假定以下上确界及相关事件可测。令确定性算法 $A_n : Z^n \to \mathcal{W}$ 可测，并在固定 $n$ 时简记 $A = A_n$。若某份样本 $S$ 及算法输出满足

$$\sup_{w} |\hat{R}_S(w) - R_{\mathcal{P}}(w)| \le \eta, \qquad \hat{R}_S(A_n(S)) \le \inf_{w} \hat{R}_S(w) + \alpha,$$

其中 $\eta, \alpha \ge 0$，则

$$R_{\mathcal{P}}(A_n(S)) \le \inf_{w} R_{\mathcal{P}}(w) + 2\eta + \alpha.$$

若对任意 $\eta, \delta \in (0,1)$，存在不依赖 $\mathcal{P}$ 的整数 $n_{\mathrm{uc}}(\eta, \delta)$，使所有 $n \ge n_{\mathrm{uc}}(\eta, \delta)$ 均满足

$$\mathbb{P}_{S \sim \mathcal{P}^n} \left\{ \sup_{w \in \mathcal{W}} |\hat{R}_S(w) - R_{\mathcal{P}}(w)| \le \eta \right\} \ge 1 - \delta \quad \text{对每个} \mathcal{P} \in \mathfrak{P},$$

且存在不依赖 $\mathcal{P}$ 的 $\alpha_n \to 0$，使每份 $S \in Z^n$ 都满足

$$\hat{R}_S(A_n(S)) \le \inf_{w \in \mathcal{W}} \hat{R}_S(w) + \alpha_n,$$

则该算法分布无关 PAC 学习此问题。

**证明**　对任意固定比较决策 $w$，依次比较期望风险、经验风险和经验最优值，得到

$$\begin{aligned} R_{\mathcal{P}}(A(S)) &\le \hat{R}_S(A(S)) + \eta \\ &\le \hat{R}_S(w) + \alpha + \eta \\ &\le R_{\mathcal{P}}(w) + \alpha + 2\eta. \end{aligned}$$

对 $w$ 取下确界即可。取 $\eta \le \varepsilon/4$、$\alpha \le \varepsilon/2$，并让一致收敛事件的概率至少为 $1-\delta$，便得到 PAC 保证。 ■

上述证明只在总体评价、样本评价与经验最优值之间作比较，并未使用凸性。它说明一致收敛配合足够小的经验优化误差能够支持学习。我们还需检验逆向：一个问题可学习时，是否必须对全部决策都能准确估计风险？

### 7.2.3 一致收敛不是必要条件

要检验这个逆向问题，可以让决策空间同时包含一个已知的好决策和很多会误导经验评价的决策。取 $Z=\mathbb{N}$，令 $w_0$ 为特殊决策，另允许每个有限集 $C\subset\mathbb{N}$ 作为决策，并定义

$$\ell(w_0,z)=0, \qquad \ell(C,z)=\mathbb{I}\{z\notin C\}.$$

$w_0$ 始终没有损失，集合决策则只在集合外受罚。所有有限子集组成可数集合，因此这个损失函数空间满足本部分的可数逼近约定。

**定理 7.3　可学习性不推出一致收敛**　令可测观测空间为 $(Z,2^Z)$，其中 $Z=\mathbb{N}$；令可测决策空间为 $\mathcal{W}=\{w_0\}\cup\{C : C\subset\mathbb{N},\, C\text{有限}\}$ 及其幂集，并允许 $Z$ 上的所有概率分布。定义可测且取值于 $\{0,1\}$ 的损失

$$\ell(w_0,z)=0, \qquad \ell(C,z)=\mathbb{I}\{z\notin C\}.$$

对每个 $n\ge 1$、每个 $Z$ 上的概率分布 $\mathcal{P}$ 及 $S\sim\mathcal{P}^n$，确定性算法 $A_n : Z^n\to\mathcal{W}$ 定义为 $A_n(S)=w_0$。该损失有界，因而算法的训练损失与独立测试损失均可积。则 $(A_n)_{n\ge1}$ 分布无关 PAC 学习该问题，但损失函数空间 $\{z\mapsto\ell(w,z) : w\in\mathcal{W}\}$ 不满足分布无关的一致收敛。

**证明**　始终输出 $w_0$ 的算法在每个分布下都具有零期望风险，因此达到最优。另一方面，对每个样本量 $n$，令 $\mathcal{P}_n$ 为 $\{1,\dots,2n\}$ 上的均匀分布。对任何 $S\sim\mathcal{P}_n^n$，记其出现过的观测构成的集合为 $C_S$。由于 $|C_S|\le n$，有

$$\hat{R}_S(C_S)=0, \qquad R_{\mathcal{P}_n}(C_S)\ge\frac{1}{2}.$$

前者因为每个样本点都属于 $C_S$，后者因为 $C_S$ 至多覆盖 $\mathcal{P}_n$ 支持集的一半。一致收敛要求同一个样本量适用于所有分布，但每个 $n$ 都有上述 $\mathcal{P}_n$ 使统一偏差以概率 1 至少为 $1/2$，所以分布无关的一致收敛不成立。 ■

在同一个决策空间里，始终选择 $w_0$ 和选择样本点集合 $C_S$ 都是 ERM，因为两者的经验风险都为零。然而，在证明采用的 $\mathcal{P}_n$ 下，前一个算法的期望风险为零，后一个至少为 $1/2$。经验最优并没有规定如何处理并列最优者，而这一选择足以改变学习结果。好的算法可以保留整个决策空间，只需始终输出 $w_0$，无需删去那些风险估计失真的 $C_S$。

这个教学构造没有否定二分类基本定理，因为它改变了损失类的结构。二分类也在 $z=(x,y)$ 上抽样，但损失必须由预测与标签是否一致产生，同一分类器不可能在 $(x,0)$ 和 $(x,1)$ 上都取零损失。这里的 $w_0$ 却对全部观测都取零损失。一般损失允许这个特殊决策，因而可以在缺少一致收敛时学习成功。接下来，我们直接分析算法的选择过程，寻找控制泛化的另一条路径。

## 7.3 算法稳定性与可学习性

上面的两个 ERM 拥有相同候选决策，却因选择方式不同而产生不同风险。我们现在固定算法，考察观测改变时输出怎样改变。可以直接比较两次输出的损失，也可以先比较参数距离，或衡量输出透露了多少训练样本信息。后两种量尚未涉及当前损失，需要 Lipschitz 性、光滑性、有界性或次高斯条件，才能转换为风险结论。优化方法以及并列经验最优者的选择规则，都可能改变这种样本依赖。

删除和替换提供两种不同的比较。留一法删除一项后重新训练，替换法则保持样本量不变；对损失变化既可以要求所有样本都满足上界，也可以只在随机抽样下取平均。参数距离和信息量提供另外两种分析算法依赖的方式。下面将把这些条件分别连接到泛化差，再与经验最优性合并；这一基本论证不要求损失凸。

连接稳定性与学习前，我们先区分需要控制的两个量。**期望泛化差**比较算法在独立观测和训练观测上的平均评价：

$$\mathbb{E}_S[R_{\mathcal{P}}(A(S))-\hat{R}_S(A(S))].$$

它是有符号偏差，为正时表示经验风险平均低估期望风险。**超额期望风险**则直接比较输出与决策空间中的最优值：

$$R_{\mathcal{P}}(A(S))-\inf_{w\in\mathcal{W}} R_{\mathcal{P}}(w).$$

即使第一个量的绝对值很小，训练和测试损失仍可能同时很大。第二个量小，才表明输出接近所选比较基准。下面的定理说明如何用经验最优性补上两者之间的距离。

**定理 7.4　期望泛化差与经验最优性**　设 $(Z,\mathcal{Z})$ 与 $(\mathcal{W},\mathcal{B}_{\mathcal{W}})$ 分别为可测观测空间和非空可测决策空间，$\ell:\mathcal{W}\times Z\to\mathbb{R}$ 可测。对每个允许分布 $\mathcal{P}$，令 $S=(z_1,\dots,z_n)\sim\mathcal{P}^n$，令算法内部随机数 $U$ 独立于 $S$，并令可测算法 $A_n:Z^n\times\mathcal{U}\to\mathcal{W}$ 输出 $A_n(S,U)$，并在固定 $n$ 时简记 $A=A_n$。再令 $z\sim\mathcal{P}$ 独立于 $S,U$，定义

$$R_{\mathcal{P}}(w)=\mathbb{E}_{z\sim\mathcal{P}}\ell(w,z),\qquad \hat{R}_S(w)=\frac{1}{n}\sum_{i=1}^{n}\ell(w,z_i).$$

假定 $\ell(A_n(S,U),z)$ 及每个 $\ell(A_n(S,U),z_i)$ 均可积；$\inf_{w\in\mathcal{W}}R_{\mathcal{P}}(w)$ 为有限实数，且 $\inf_{w\in\mathcal{W}}\hat{R}_S(w)$ 可测且几乎处处为有限实数。若对所有允许分布均有

$$\mathbb{E}_{S,U}[R_{\mathcal{P}}(A_n(S,U))-\hat{R}_S(A_n(S,U))]\le g_n,$$

以及

$$\mathbb{E}_{S,U}\Big[\hat{R}_S(A_n(S,U))-\inf_{w\in\mathcal{W}}\hat{R}_S(w)\Big]\le\rho_n,$$

其中 $g_n,\rho_n$ 为不依赖具体分布的非负数，则

$$\mathbb{E}_{S,U}R_{\mathcal{P}}(A_n(S,U))-\inf_{w\in\mathcal{W}}R_{\mathcal{P}}(w)\le g_n+\rho_n.\tag{7.1}$$

若 $g_n+\rho_n\to 0$，则算法分布无关 PAC 学习此问题；条件 $g_n+\rho_n\le\varepsilon\delta$ 足以使超额期望风险超过 $\varepsilon$ 的概率不超过 $\delta$。

**证明**　固定任意不依赖样本且风险有限的 $w\in\mathcal{W}$，将期望风险差分解为

$$\begin{aligned}\mathbb{E}[R_{\mathcal{P}}(A(S,U))-R_{\mathcal{P}}(w)]&=\mathbb{E}[R_{\mathcal{P}}(A(S,U))-\hat{R}_S(A(S,U))]\\&\quad+\mathbb{E}[\hat{R}_S(A(S,U))-\hat{R}_S(w)]\\&\quad+\mathbb{E}[\hat{R}_S(w)-R_{\mathcal{P}}(w)].\end{aligned}$$

三项分别不超过 $g_n$、$\rho_n$ 和 $0$，其中第三项恰为零。对 $w$ 取下确界得到式 (7.1)。由于输出属于比较空间，超额期望风险非负；对它应用 Markov 不等式即可得到概率结论。 ■

不同稳定性定义改变了扰动方式与平均对象。平均留一法把 $n$ 项样本减为 $n-1$ 项，在被删观测上比较损失绝对差，再对样本和删除位置取平均，因此联系的是两个样本量下的风险。均匀稳定性改为替换一项，要求任意相邻样本和任意测试观测上的损失差均受控；有界损失下，这种要求

还能给出高概率界。平均稳定性也使用替换，但对样本、新观测、替换位置及算法随机性取平均，直接对应期望泛化差。

若输出是参数，我们还可以在共享算法随机数下比较两次参数的距离，再通过 Lipschitz 性转成损失差。非负光滑损失的自界关系提供另一种转换：当前损失值可以控制梯度范数。互信息方法则绕过相邻样本，直接量化输出与整份样本的统计依赖；条件互信息先在每个位置给出两个备选观测，再衡量输出透露了多少选择信息。两者都能控制期望泛化差，条件互信息还可结合经验最优性刻画学习算法的存在。使用这些结论时，必须保留各自的量词、常数和损失条件。

下面的期望运算需要明确的可积性条件。令 $z, z_i' \sim \mathcal{P}$ 独立于 $S, U$，用 $S^{(i)}$ 表示替换 $z_i$ 的样本，$S^{\setminus i}$ 表示删除 $z_i$ 的样本。对实际使用的样本量和允许分布，独立测试损失 $\ell(A_n(S,U),z)$、训练损失 $\ell(A_n(S,U),z_i)$ 与替换损失 $\ell(A_n(S^{(i)},U),z_i)$ 均要求属于 $L^1$。删除型结论还要求 $\ell(A_{n-1}(S^{\setminus i},U),z_i) \in L^1$；固定比较决策 $w$ 要求 $\ell(w,z) \in L^1$。若使用经验风险的下确界，要求它可测且几乎处处为有限实数；期望风险的下确界要求为有限实数。后文将这组要求称为“稳定性可积性条件”。损失有界时，所列损失的可积性自动成立。

### 7.3.1 留一法稳定性

训练观测参与了决策选择，因而不能直接充当独立测试点。我们可以删除 $z_i$，用剩下的样本训练，再在 $z_i$ 上评价输出。记 $n$ 项算法为 $A_n$、删减样本为 $S^{\setminus i}$，则 $z_i$ 独立于 $S^{\setminus i}$，能够评价 $A_{n-1}(S^{\setminus i})$ 面对新观测时的损失。对所有删除位置平均，便得到留一法估计。

**定义 7.5　留一法风险估计**　对确定性学习算法序列 $(A_n)_{n\ge 1}$，$n \ge 2$ 时的留一法风险估计定义为

$$\hat{R}_S^{\mathrm{loo}}(A) = \frac{1}{n}\sum_{i=1}^{n} \ell(A_{n-1}(S^{\setminus i}), z_i).$$

计算这一估计时，每个位置都需要在相应删减样本上重新训练。经验风险在 $z_i$ 处使用已见过 $z_i$ 的决策，留一法则使用未见过它的决策。留一法稳定性（leave-one-out stability）控制这两个决策在被删观测上的损失差，从而把两种评价联系起来。

**定义 7.6　平均留一法稳定性**　若对每个允许分布 $\mathcal{P}$ 都有

$$\frac{1}{n}\sum_{i=1}^{n}\mathbb{E}_{S\sim\mathcal{P}^n}\left|\ell(A_n(S),z_i)-\ell(A_{n-1}(S^{\setminus i}),z_i)\right|\le\beta_n^{\mathrm{loo}},$$

则称算法序列具有速率 $\beta_n^{\mathrm{loo}}$ 的分布无关平均留一法稳定性。

上述条件只在被删观测上评价，并对样本及删除位置取平均。它允许个别样本或位置出现较大变化，不要求任意测试点都满足相同上界。留一法稳定性还有概率型和二阶矩型定义，这里采用的是平均绝对差版本[3]。

我们用样本均值检验这个条件。设 $z_i\in[0,1]$，输出 $\bar z$，并用绝对损失评价。删除第 $i$ 项得到 $\bar z_{-i}$，由 $\bar z-\bar z_{-i}=(z_i-\bar z_{-i})/n$ 可知输出距离至多 $1/n$；再对绝对损失应用三角不等式，得到 $\beta_n^{\mathrm{loo}}\le 1/n$。这只验证了删除稳定性。均值是否使绝对损失最小，是另一个问题，例子没有作出这个断言。

[3] O. Bousquet, A. Elisseeff, *Stability and Generalization* In Journal of Machine Learning Research, 2002, vol. 2, pp. 499–526

**定理 7.7　留一法稳定性与期望风险**　设 $(Z,\mathcal{Z})$ 与 $(\mathcal{W},\mathcal{B}_{\mathcal{W}})$ 为可测空间，$\ell:\mathcal{W}\times Z\to\mathbb{R}$ 可测，确定性算法 $A_k:Z^k\to\mathcal{W}$ 对每个 $k\ge 1$ 均可测。固定 $n\ge 2$ 和允许分布 $\mathcal{P}$，令 $S=(z_1,\dots,z_n)\sim\mathcal{P}^n$，并以 $S^{\setminus i}$ 表示删除 $z_i$ 所得的样本。定义

$$R_{\mathcal{P}}(w)=\mathbb{E}_{z\sim\mathcal{P}}\ell(w,z),\qquad \hat R_S(w)=\frac{1}{n}\sum_{i=1}^{n}\ell(w,z_i).$$

假定 $\ell(A_n(S),z_i)$ 与 $\ell(A_{n-1}(S^{\setminus i}),z_i)$ 对每个 $i$ 均可积。若 $\beta_n^{\mathrm{loo}}\ge 0$ 且

$$\frac{1}{n}\sum_{i=1}^{n}\mathbb{E}_S\left|\ell(A_n(S),z_i)-\ell(A_{n-1}(S^{\setminus i}),z_i)\right|\le\beta_n^{\mathrm{loo}},$$

则对 $T\sim\mathcal{P}^{n-1}$ 有

$$\left|\mathbb{E}_T R_{\mathcal{P}}(A_{n-1}(T))-\mathbb{E}_S\hat R_S(A_n(S))\right|\le\beta_n^{\mathrm{loo}}.$$

**证明**　被删去的 $z_i$ 独立于 $S^{\setminus i}$，所以

$$\mathbb{E}_S\hat R_S^{\mathrm{loo}}(A)=\mathbb{E}_{T\sim\mathcal{P}^{n-1}}R_{\mathcal{P}}(A_{n-1}(T)).$$

两侧减去 $\mathbb{E}_S\hat R_S(A_n(S))$，再对左侧取绝对值。三角不等式将它控制为各项删除前后损失绝对差的平均，至多为 $\beta_n^{\mathrm{loo}}$。 ■

定理联系的是 $n$ 项经验评价与 $n-1$ 项训练后的总体评价。少一项样本正是为了让评价点独立于训练，因此它没有直接给出 $A_n$ 自身的期望泛化

差。两种评价接近也不足以说明学习成功，因为它们可能同时很高。我们还要要求 $n$ 项算法的经验风险接近经验最优值。

**定理 7.8　留一法稳定性与可学习性**　设 $(Z, \mathcal{Z})$ 与 $(\mathcal{W}, \mathcal{B}_{\mathcal{W}})$ 分别为可测观测空间和非空可测决策空间，$\ell : \mathcal{W} \times Z \to \mathbb{R}$ 可测，确定性算法 $A_k : Z^k \to \mathcal{W}$ 对每个 $k \geq 1$ 均可测。对每个允许分布 $\mathcal{P}$、$n \geq 2$ 及 $S = (z_1, \dots, z_n) \sim \mathcal{P}^n$，以 $S^{\setminus i}$ 表示删除 $z_i$ 所得的样本，并定义

$$R_{\mathcal{P}}(w) = \mathbb{E}_{z \sim \mathcal{P}} \ell(w, z), \qquad \hat{R}_S(w) = \frac{1}{n} \sum_{i=1}^{n} \ell(w, z_i).$$

假定 $\ell(A_n(S), z_i)$、$\ell(A_{n-1}(S^{\setminus i}), z_i)$ 及 $\ell(w, z)$ 对每个 $i$ 和每个固定 $w \in \mathcal{W}$ 均可积，并假定出现的风险下确界为有限实数且可测。若存在不依赖 $\mathcal{P}$ 的非负数 $\beta_n^{\mathrm{loo}}, \rho_n$，使

$$\frac{1}{n} \sum_{i=1}^{n} \mathbb{E}_S \left| \ell(A_n(S), z_i) - \ell(A_{n-1}(S^{\setminus i}), z_i) \right| \leq \beta_n^{\mathrm{loo}}$$

并且

$$\mathbb{E}_S \left[ \hat{R}_S(A_n(S)) - \inf_{w \in \mathcal{W}} \hat{R}_S(w) \right] \leq \rho_n.$$

则对 $T \sim \mathcal{P}^{n-1}$，

$$\mathbb{E}_T R_{\mathcal{P}}(A_{n-1}(T)) - \inf_{w \in \mathcal{W}} R_{\mathcal{P}}(w) \leq \beta_n^{\mathrm{loo}} + \rho_n.$$

若 $\beta_n^{\mathrm{loo}} \to 0$ 且 $\rho_n \to 0$，则该算法序列 PAC 学习此问题。使用 $m$ 个观测达到精度 $\varepsilon$ 与置信度 $1 - \delta$ 的一个充分条件是 $\beta_{m+1}^{\mathrm{loo}} + \rho_{m+1} \leq \varepsilon\delta$。

**证明**　对任意不依赖样本的 $w \in \mathcal{W}$，经验优化误差条件给出

$$\mathbb{E}_S \hat{R}_S(A_n(S)) \leq \mathbb{E}_S \hat{R}_S(w) + \rho_n = R_{\mathcal{P}}(w) + \rho_n.$$

代入定理 7.7，再对 $w$ 取下确界，得到超额期望风险的期望上界。对非负的超额期望风险应用 Markov 不等式，失败概率至多为 $(\beta_n^{\mathrm{loo}} + \rho_n)/\varepsilon$。令 $m = n - 1$ 即得所述样本量条件。 ■

在所得上界中，$\beta_n^{\mathrm{loo}}$ 控制删除后独立评价与原经验评价的距离，$\rho_n$ 控制算法距离经验最优值的差。两项以分布无关的速率趋于零，才共同给出学习保证。后面的必要性结果采用样本量不变的替换定义，不能将其直接解释为当前删除条件的必要性。

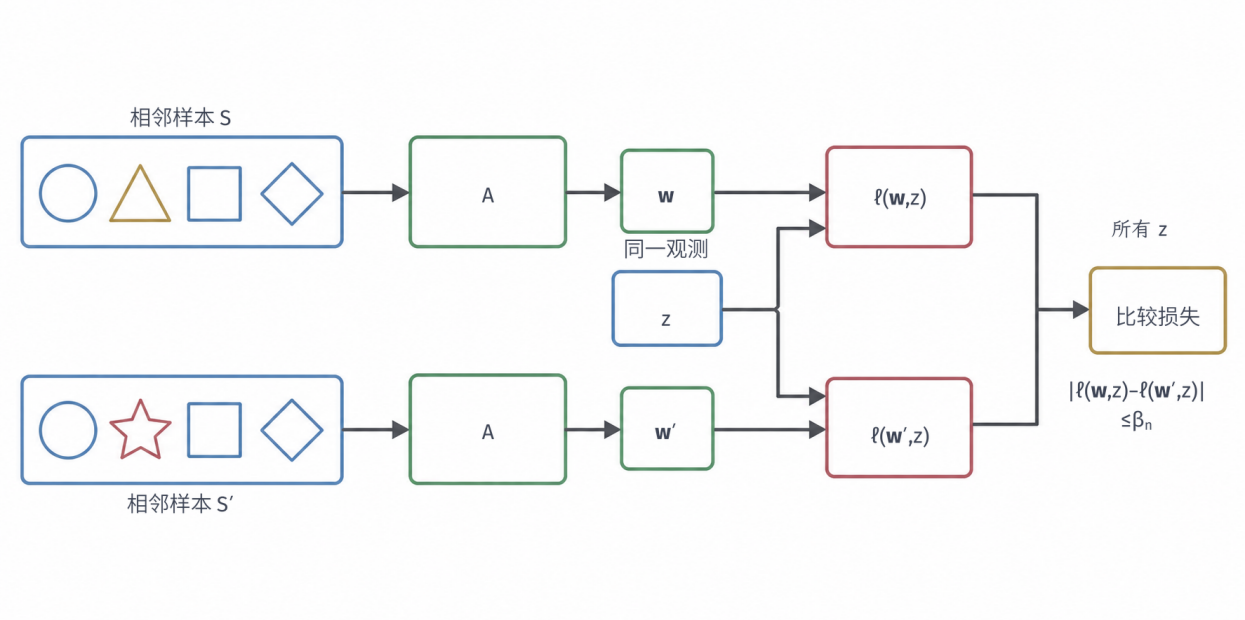


图 7.1 算法稳定性的相邻样本实验。两批样本只替换一个观测，同一算法分别输出 $\boldsymbol{w} = A(S)$ 与 $\boldsymbol{w}' = A(S')$。两次输出在同一测试点 $z$ 上计算损失，再比较绝对差；均匀稳定性要求所有这样的损失差都不超过 $\beta_n$。图中的比较对象是损失，不是参数距离。

### 7.3.2 均匀稳定性

留一法只对删除位置作平均比较。如果我们要求每次改变一个观测都只造成有限的测试损失变化，就要同时控制所有样本和测试观测。均匀稳定性（uniform stability）表达这一要求；这里采用保持样本量不变的替换方式。

两份样本仅第 $i$ 项不同时，称为相邻样本，记为 $S$ 与 $S^{(i)}$。我们分别运行同一个算法，并在同一测试观测上比较输出损失，以便只考察被替换观测的影响。

图 7.1固定了这个比较过程：两份样本共享其余观测，算法设置也相同，仅替换一项。如果这一改动使某个测试点上的损失大幅改变，算法就对该项观测敏感。若每个位置造成的损失变化都有统一小上界，我们便可以逐项用独立观测替代训练观测的自我影响，进而控制泛化差。

由于我们希望控制每一种单项替换，上界必须同时覆盖所有相邻样本及所有测试观测。

**定义 7.9 均匀稳定性** 若对任意相邻 $S, S'$ 和任意 $z \in Z$ 都有

$$|\ell(A(S), z) - \ell(A(S'), z)| \le \beta_n, \tag{7.2}$$

则称算法 $A$ 具有 $\beta_n$ 均匀稳定性。

定义中固定 $n$，将 $A_n$ 简记为 $A$。均匀稳定性只比较算法在相邻样本上实际产生的两个输出；一致收敛则估计整个决策空间的风险。两者控制的对象因而不同。

替换保持 $n$ 不变，删除却改变 $n$，所以两种条件不能直接互推。例如，算法按样本量的奇偶输出两个常量，替换观测不改变输出，删除一项却会使输出跳变。如果另有对任意测试观测成立的均匀删除稳定性，则两份相邻样本都可删去被替换位置，成为同一份 $n-1$ 项样本。每次删除的损失变化若至多 $\beta_n^{\mathrm{del}}$，经过这份共同样本比较两次输出，三角不等式给出 $2\beta_n^{\mathrm{del}}$ 的替换上界。

继续使用 $z_i \in [0,1]$ 的样本均值 $A(S)=\bar z$，这次替换而非删除一项。均值变化至多 $1/n$，对绝对损失 $\ell(w,z)=|w-z|$，在同一个测试观测 $z$ 处有

$$\bigl|\,|\bar z - z| - |\bar z' - z|\,\bigr| \le |\bar z - \bar z'| \le \frac{1}{n}.$$

这个界同时覆盖所有相邻样本和测试点，因此验证了 $1/n$ 均匀稳定性。它与前面的删除例子分别检验两种扰动；两者都没有证明均值最小化绝对损失，经验拟合仍需单独检查。

**定理 7.10　均匀稳定性与期望风险**　设 $(Z,\mathcal{Z})$ 与 $(\mathcal{W},\mathcal{B}_{\mathcal{W}})$ 为可测空间，$\ell:\mathcal{W}\times Z\to\mathbb{R}$ 可测，$\mathcal{P}$ 为 $Z$ 上的概率分布，$S=(z_1,\dots,z_n)\sim\mathcal{P}^n$，且确定性算法 $A:Z^n\to\mathcal{W}$ 可测。令 $z_i'\sim\mathcal{P}$ 独立于 $S$，并以 $S^{(i)}$ 表示用 $z_i'$ 替换 $z_i$ 所得的样本。定义

$$R_{\mathcal{P}}(w)=\mathbb{E}_{z\sim\mathcal{P}}\ell(w,z),\qquad \hat R_S(w)=\frac{1}{n}\sum_{i=1}^{n}\ell(w,z_i).$$

假定 $\ell(A(S),z_i)$、$\ell(A(S),z_i')$ 和 $\ell(A(S^{(i)}),z_i')$ 均可积。若任意只相差一个观测的 $s,s'\in Z^n$ 及任意 $z\in Z$ 都满足

$$|\ell(A(s),z)-\ell(A(s'),z)|\le\beta_n,$$

则

$$\bigl|\mathbb{E}_S\bigl[R_{\mathcal{P}}(A(S))-\hat R_S(A(S))\bigr]\bigr|\le\beta_n. \tag{7.3}$$

**证明**　取与 $S$ 独立的 $z_i'\sim\mathcal{P}$，令 $S^{(i)}$ 把 $z_i$ 替换为 $z_i'$。交换 $z_i$ 与 $z_i'$ 不改变全部独立观测的联合分布，因而 $(S,z_i)$ 与 $(S^{(i)},z_i')$ 同分布。这使

经验风险项可写成 $\mathbb{E}\ell(A(S^{(i)}), z_i')$，而期望风险项为 $\mathbb{E}\ell(A(S), z_i')$。因此

$$\begin{aligned}&\mathbb{E}_S[R_{\mathcal{P}}(A(S)) - \hat{R}_S(A(S))]\\ &= \frac{1}{n}\sum_i \mathbb{E}[\ell(A(S), z_i') - \ell(A(S^{(i)}), z_i')] \le \beta_n.\end{aligned}$$

交换 $S$ 与 $S^{(i)}$ 得到反向界。

■

这个交换论证把 $z_i'$ 的作用从独立测试点改成了 $S^{(i)}$ 中的训练点。可交换性使替换后的训练损失与原训练损失具有相同期望，均匀稳定性再控制同一 $z_i'$ 上两次输出的损失差。所需可积性保证这些期望有限。整个论证只使用算法输出，没有对所有决策取上确界。

结果中的绝对值放在期望之外，因而不同样本上的正负泛化差可以抵消；它既不是绝对泛化差的平均，也不是逐样本保证。若算法随机化为 $A(S, U)$，我们采用先对内部随机性平均的定义：

$$\sup_{S, S' \text{相邻}, z \in Z} \left| \mathbb{E}_U \ell(A(S, U), z) - \mathbb{E}_U \ell(A(S', U), z) \right| \le \beta_n.$$

这里 $U$ 与样本独立，且每个固定 $S, z$ 下的 $\ell(A(S, U), z)$ 关于 $U$ 可积。将确定性证明再对 $U$ 平均，便控制 $S, U$ 共同平均的泛化差，仍不保证每次随机运行都稳定。留一法也可以先平均内部随机性，再比较删除前后的损失绝对差；其风险恒等式和学习保证同样保留。

要把这个泛化结论用于学习，还需控制经验优化误差。若输出属于 $\mathcal{W}$ 且期望经验优化误差至多 $\rho_n$，在定理 7.4中令 $g_n = \beta_n$，就得到 $\beta_n + \rho_n$ 的平均超额风险界及相应 PAC 保证。仅有 $\beta_n \to 0$，而经验风险始终远离最优值，仍不能完成学习。这里给出的是验证一个算法的充分条件，尚未要求每个成功算法都均匀稳定。

如果只想在一份样本上用经验风险估计期望风险，而暂不比较最优决策，就需要控制泛化差的随机波动。有界损失配合均匀稳定性，使替换一项对整个泛化差的影响有统一上界，因此可以应用集中不等式。下面先固定确定性算法，单独处理样本随机性。

**定理 7.11　均匀稳定性的高概率泛化界**　设 $(Z, \mathcal{Z})$ 与 $(\mathcal{W}, \mathcal{B}_{\mathcal{W}})$ 为可测空间，$\ell : \mathcal{W} \times Z \to [0,1]$ 可测，$\mathcal{P}$ 为 $Z$ 上的概率分布，$S = (z_1, \dots, z_n) \sim \mathcal{P}^n$，且确定性算法 $A : Z^n \to \mathcal{W}$ 可测。定义

$$R_{\mathcal{P}}(w) = \mathbb{E}_{z\sim\mathcal{P}}\ell(w,z), \qquad \hat{R}_S(w) = \frac{1}{n}\sum_{i=1}^{n}\ell(w,z_i).$$

若任意只相差一个观测的 $s, s' \in Z^n$ 及任意 $z \in Z$ 都满足

$$|\ell(A(s),z) - \ell(A(s'),z)| \le \beta_n,$$

则任意 $\delta \in (0,1)$ 下，以至少 $1-\delta$ 的样本概率，有

$$|R_{\mathcal{P}}(A(S)) - \hat{R}_S(A(S))| \le \beta_n + (2n\beta_n + 1)\sqrt{\frac{\log(2/\delta)}{2n}}.$$

**证明**　记 $g(S) = R_{\mathcal{P}}(A(S)) - \hat{R}_S(A(S))$。替换一个观测后，期望风险变化至多 $\beta_n$；经验风险的 $n-1$ 个共同观测各变化至多 $\beta_n$，被替换项变化至多 1。因此 $|g(S) - g(S')| \le 2\beta_n + 1/n$。对 $n$ 个独立观测应用有界差分不等式，$g(S)$ 偏离其期望的绝对值以至少 $1-\delta$ 的概率不超过 $(2n\beta_n+1)\sqrt{\log(2/\delta)/(2n)}$。再使用 $|\mathbb{E}g(S)| \le \beta_n$ 即得结论。 ■

当 $\beta_n = O(1/n)$ 时，这个直接界随 $n$ 增大而下降；若稳定性下降较慢，因子 $n\beta_n$ 会使估计过于宽松。更精细的集中分析给出

$$|R_{\mathcal{P}}(A(S)) - \hat{R}_S(A(S))| \le C\left(\beta_n \log(2n)\log\frac{2}{\delta} + \sqrt{\frac{\log(2/\delta)}{n}}\right),$$

其中 $C$ 为通用常数。这是 Bousquet、Klochkov 与 Zhivotovskiy 的高概率结果，其高阶矩证明不在此展开[4]。随机算法可以将这一结论用于内部随机性平均后的损失；若要评价单次随机输出，还须另外控制内部随机性。

我们已经知道怎样用稳定性验证给定算法。现在换一个问题：只要学习问题可学习，能否构造同时稳定且经验风险接近最优的算法？这一存在性问题需要把经验最优性加强为对每份样本都成立的要求。

**定义 7.12　始终渐近经验风险最小化**　设随机算法 $A(S,U)$ 的输出属于 $\mathcal{W}$，$U$ 独立于样本。若存在 $\rho_n \to 0$，使任意 $S \in Z^n$ 均满足

$$\mathbb{E}_U \hat{R}_S(A(S,U)) - \inf_{w\in\mathcal{W}} \hat{R}_S(w) \le \rho_n,$$

[4] O. Bousquet, Y. Klochkov, N. Zhivotovskiy, *Sharper Bounds for Uniformly Stable Algorithms* In Proceedings of the Thirty Third Conference on Learning Theory, 2020, pp. 610–626

则称 $A$ 为始终渐近经验风险最小化算法（always AERM）。

“始终”限定的是样本：每份样本都必须满足同一个 $\rho_n$ 上界，只有内部随机性被平均。若对每个允许分布下的样本取期望后才满足分布无关速率，则称为分布无关 AERM。下面采用更强的始终 AERM，将算法存在性与可学习性联系起来[5]。

**定理 7.13　一般学习基本定理：均匀稳定性与可学习性**　设 $(Z, \mathcal{Z})$ 与 $(\mathcal{W}, \mathcal{B}_{\mathcal{W}})$ 为可测空间，$\mathcal{W}$ 非空，$\ell : \mathcal{W} \times Z \to [0,1]$ 可测，并允许 $Z$ 上的所有概率分布。对每个 $n$，假定 $s \mapsto \inf_{w \in \mathcal{W}} n^{-1} \sum_{i=1}^{n} \ell(w, z_i)$ 可测；随机算法均由可测映射 $A_n : Z^n \times \mathcal{U} \to \mathcal{W}$ 表示，其内部随机数 $U$ 与样本 $S \sim \mathcal{P}^n$ 独立。定义

$$R_{\mathcal{P}}(w) = \mathbb{E}_{z \sim \mathcal{P}} \ell(w, z), \qquad \hat{R}_S(w) = \frac{1}{n} \sum_{i=1}^{n} \ell(w, z_i).$$

则以下两个命题等价：

1. 存在随机算法 $(B_n)$，使任意 $\varepsilon, \delta \in (0,1)$ 都有不依赖 $\mathcal{P}$ 的 $n_0(\varepsilon, \delta)$，并且所有 $n \geq n_0$ 均满足

$$\mathbb{P}_{S,U}\left\{ R_{\mathcal{P}}(B_n(S,U)) - \inf_{w \in \mathcal{W}} R_{\mathcal{P}}(w) \leq \varepsilon \right\} \geq 1 - \delta$$

   对每个 $Z$ 上的概率分布 $\mathcal{P}$ 成立；

2. 存在随机算法 $(A_n)$ 及不依赖 $\mathcal{P}$ 的非负序列 $\rho_n \to 0$、$\beta_n \to 0$，使每份 $s \in Z^n$ 都满足

$$\mathbb{E}_U \hat{R}_s(A_n(s,U)) - \inf_{w \in \mathcal{W}} \hat{R}_s(w) \leq \rho_n,$$

   而任意只相差一个观测的 $s, s' \in Z^n$ 及任意 $z \in Z$ 都满足

$$\left| \mathbb{E}_U \ell(A_n(s,U), z) - \mathbb{E}_U \ell(A_n(s',U), z) \right| \leq \beta_n.$$

**证明**　命题 2 蕴含命题 1：定理 7.10给出 $g_n = \beta_n$ 的期望泛化差上界，再由定理 7.4得到 PAC 保证。

逆向从已有学习算法 $B$ 出发。因为损失有界，我们可将超额期望风险按 PAC 成功和失败事件分开：成功时至多 $\varepsilon$，失败时至多 1，故期望至多 $\varepsilon + \delta$。让两项随样本量下降，就得到分布无关的平均超额期望风险上界 $a_k \to 0$。

利用 $B$ 构造新的算法。对输入 $S$，有放回地独立抽取 $k=\lfloor\sqrt{n}\rfloor$ 个位置 $J=(J_1,\dots,J_k)$，将对应序列 $T$ 交给 $B$。若 $B$ 还使用随机数 $U_0$，新算法的随机数就是 $U=(J,U_0)$。固定 $S$ 后，$T$ 独立取自经验分布 $\mathcal{P}_S=n^{-1}\sum_i \delta_{z_i}$，其中 $\delta_{z_i}$ 为点质量分布。由于 $R_{\mathcal{P}_S}(w)=\hat{R}_S(w)$，$B$ 在这一分布上的学习保证给出

$$\mathbb{E}_{J,U_0}\hat{R}_S(B(T,U_0))-\inf_w \hat{R}_S(w)\le a_k.$$

经验分布可以来自任意 $S$，因此新算法对每份样本都满足 AERM，且 $\rho_n=a_k\to 0$。

在相邻样本上共享索引 $J$ 及随机数 $U_0$，两次输出只有访问被替换位置时才可能不同。访问该位置的概率至多 $k/n$，损失变化至多 1，所以 $\beta_n\le k/n\to 0$。构造的算法同时满足稳定性与始终 AERM，逆向因此成立。 ■

逆向证明改变了算法，说明存在一个稳定的学习算法，并未证明已有的每个成功算法都稳定。有放回子样本构造也只承担存在性证明，不提供最优的样本效率或计算效率。

### 7.3.3 平均稳定性

均匀稳定性控制所有相邻样本上的最大损失变化，但定理 7.10的泛化证明最后只使用随机抽样下的平均变化。某些大变化如果很少出现，对平均泛化差的贡献便可能较小。为了保留这种分布信息，我们直接计算随机替换一项带来的平均损失变化。

仍令 $S=(z_1,\dots,z_n)\sim\mathcal{P}^n$，用独立 $z_i'\sim\mathcal{P}$ 替换 $z_i$ 得到 $S^{(i)}$，但这次在被替换出去的 $z_i$ 上评价。$A(S)$ 见过 $z_i$，$A(S^{(i)})$ 未见过它，两者的损失差衡量训练使用 $z_i$ 在该观测上带来的优势。对样本、新观测与位置取平均，得到**平均稳定性**（on-average stability）。这里采用一侧的平均替换定义，与《Understanding Machine Learning》第 13 章的约定一致[6]。

**定义 7.14　平均稳定性**　设 $U$ 为独立于所有观测的算法内部随机数，并满足稳定性可积性条件。定义

$$\gamma_n(A,\mathcal{P})=\frac{1}{n}\sum_{i=1}^{n}\mathbb{E}_{S,z_i',U}\left[\ell(A(S^{(i)},U),z_i)-\ell(A(S,U),z_i)\right]. \tag{7.4}$$

给定 $\bar{\beta}_n(\mathcal{P})\ge 0$，若 $\gamma_n(A,\mathcal{P})\le\bar{\beta}_n(\mathcal{P})$，则称算法在分布 $\mathcal{P}$ 下具有速率 $\bar{\beta}_n(\mathcal{P})$ 的平均稳定性。若对所有允许分布均有 $\gamma_n(A,\mathcal{P})\le\bar{\beta}_n$，且 $\bar{\beta}_n$ 不依赖 $\mathcal{P}$，则称算法具有速率 $\bar{\beta}_n$ 的分布无关平均稳定性。

确定性算法可省略 $U$。定义平均有符号差，因此不同样本上的增减可以抵消；只限制平均增加量，不限制每次替换的绝对变化。先对每项取绝对值再平均是更强的要求。均匀稳定性能够推出这里的平均条件，反向一般失败。与平均留一法相比，当前两次训练都使用 $n$ 项样本，而留一法连接 $n$ 项与 $n-1$ 项算法。

**定理 7.15　平均稳定性与期望风险**　设 $(Z,\mathcal{Z})$ 与 $(\mathcal{W},\mathcal{B}_{\mathcal{W}})$ 为可测空间，$\ell:\mathcal{W}\times Z\to\mathbb{R}$ 可测，$\mathcal{P}$ 为 $Z$ 上的概率分布。令 $S=(z_1,\dots,z_n)\sim\mathcal{P}^n$，令 $z_1',\dots,z_n'\sim\mathcal{P}$ 彼此独立并独立于 $S$，以 $S^{(i)}$ 表示用 $z_i'$ 替换 $z_i$ 所得的样本。令算法内部随机数 $U$ 独立于所有观测，且可测算法 $A:Z^n\times\mathcal{U}\to\mathcal{W}$ 输出 $A(S,U)$。再令 $z\sim\mathcal{P}$ 独立于 $S,U,z_1',\dots,z_n'$。假定 $\ell(A(S,U),z_i)$、$\ell(A(S^{(i)},U),z_i)$ 以及独立测试损失 $\ell(A(S,U),z)$ 均可积。定义

$$R_{\mathcal{P}}(w)=\mathbb{E}_{z\sim\mathcal{P}}\ell(w,z),\qquad \hat{R}_S(w)=\frac{1}{n}\sum_{i=1}^{n}\ell(w,z_i),$$

并定义

$$\gamma_n(A,\mathcal{P})=\frac{1}{n}\sum_{i=1}^{n}\mathbb{E}_{S,z_i',U}\left[\ell(A(S^{(i)},U),z_i)-\ell(A(S,U),z_i)\right].$$

则

$$\mathbb{E}_{S,U}\left[R_{\mathcal{P}}(A(S,U))-\hat{R}_S(A(S,U))\right]=\gamma_n(A,\mathcal{P}).\tag{7.5}$$

因此，若 $\bar{\beta}_n(\mathcal{P})\ge 0$ 且 $\gamma_n(A,\mathcal{P})\le\bar{\beta}_n(\mathcal{P})$，则

$$\mathbb{E}_{S,U}R_{\mathcal{P}}(A(S,U))\le\mathbb{E}_{S,U}\hat{R}_S(A(S,U))+\bar{\beta}_n(\mathcal{P}).$$

**证明**　替换后，$S^{(i)}$ 仍由 $n$ 个独立同分布的观测组成，而且独立于被替换出去的 $z_i$。在给定 $S^{(i)}$ 和 $U$ 时，对 $z_i$ 取期望得到

$$\mathbb{E}_{z_i}\ell(A(S^{(i)},U),z_i)=R_{\mathcal{P}}(A(S^{(i)},U)).$$

再利用 $S^{(i)}$ 与 $S$ 同分布，得到 $\mathbb{E}\ell(A(S^{(i)},U),z_i)=\mathbb{E}_{S,U}R_{\mathcal{P}}(A(S,U))$。另一方面，$n$ 个原观测上的损失平均恰好是经验风险，故

$$\frac{1}{n}\sum_{i=1}^{n}\mathbb{E}_{S,U}\ell(A(S,U),z_i)=\mathbb{E}_{S,U}\hat{R}_S(A(S,U)).$$

两式相减即得恒等式，再代入平均稳定性上界，得到期望风险的上界。 ■

恒等式揭示了平均替换分析的直接对象：它就是总体风险减去经验风险后的平均值，正值表示经验评价偏低，负值表示偏高。这是多次抽样和训练后的关系，单次训练的泛化差仍可能较大，绝对差的平均也未必小。若速率只对固定 $\mathcal{P}$ 成立，结论也只限于该分布；分布无关学习还需统一上界。

平均稳定性现在提供了风险分解中的 $g_n$。要比较输出与最优决策，我们同样必须加入经验优化误差。

假设 $A(S,U)\in\mathcal{W}$ 满足分布无关平均稳定性上界 $\bar{\beta}_n$，并且经验优化误差满足

$$\mathbb{E}_{S,U}[\hat{R}_S(A(S,U))-\inf_{w}\hat{R}_S(w)]\le\rho_n.$$

将定理 7.15得到的 $g_n=\bar{\beta}_n$ 代入定理 7.4，便有

$$\mathbb{E}_{S,U}R_{\mathcal{P}}(A(S,U))-\inf_{w\in\mathcal{W}}R_{\mathcal{P}}(w)\le\bar{\beta}_n+\rho_n. \tag{7.6}$$

当 $\bar{\beta}_n\to0$ 且 $\rho_n\to0$ 时，算法 PAC 学习该问题；$\bar{\beta}_n+\rho_n\le\varepsilon\delta$ 给出失败概率不超过 $\delta$ 的充分条件。

概率转换针对的是非负超额期望风险，不能直接对有符号泛化差使用 Markov 不等式。固定分布下的速率可以给出固定分布的保证；只有两项上界同时不依赖分布，才得到分布无关 PAC 结论。

沿用均值估计，可以直接算出这种分布依赖。令 $z\in[0,1]$ 具有均值 $\mu$ 和方差 $\sigma^2$，输出 $\bar{z}$，这次用平方损失 $\ell(w,z)=(w-z)^2$ 评价。对独立观测，$R_{\mathcal{P}}(\bar{z})=\sigma^2+(\bar{z}-\mu)^2$，因此

$$\mathbb{E}_S R_{\mathcal{P}}(\bar{z})=\sigma^2+\frac{\sigma^2}{n}.$$

经验评价可用 $\sum_i(z_i-\bar{z})^2=\sum_i(z_i-\mu)^2-n(\bar{z}-\mu)^2$ 计算，得到

$$\mathbb{E}_S\hat{R}_S(\bar{z})=\sigma^2-\frac{\sigma^2}{n},\qquad \gamma_n(A,\mathcal{P})=\frac{2\sigma^2}{n}.$$

方差越小，平均替换损失变化越小；观测恒定、即 $\sigma^2=0$ 时，该量为零。若只知道取值范围，$\sigma^2\le1/4$ 给出分布无关上界 $1/(2n)$。相比之下，对 $w,w',z\in[0,1]$ 有 $|(w-z)^2-(w'-z)^2|=|w-w'||w+w'-2z|\le2|w-w'|$，替换使均值移动至多 $1/n$，因此均匀稳定性上界为 $2/n$。平均分析保留了这一最坏情形估计没有使用的方差。样本均值恰为平方损失的经验最优解，故 $\rho_n=0$，稳定性法给出平均超额风险至多 $2\sigma^2/n$。直接计算则得到精确值 $\mathbb{E}(\bar{z}-\mu)^2=\sigma^2/n$，两者同阶，但稳定性常数较宽松。由方差界可知，$n\ge1/(2\varepsilon\delta)$ 足以满足这条分析的 PAC 要求。

平均条件弱于均匀条件，但我们讨论的是算法存在性时，可以在两者之间建立相同的可学习性刻画。

**定理 7.16 一般学习基本定理的平均稳定性形式** 设 $(Z,\mathcal{Z})$ 与 $(\mathcal{W},\mathcal{B}_{\mathcal{W}})$ 为可测空间，$\mathcal{W}$ 非空，$\ell:\mathcal{W}\times Z\to[0,1]$ 可测，并允许 $Z$ 上的所有概率分布。对每个 $n$，假定 $s\mapsto \inf_{w\in\mathcal{W}} n^{-1}\sum_{i=1}^{n}\ell(w,z_i)$ 可测；随机算法均由可测映射 $A_n:Z^n\times\mathcal{U}\to\mathcal{W}$ 表示，其内部随机数 $U$ 与全部观测独立。令 $S=(z_1,\dots,z_n)\sim\mathcal{P}^n$，令 $z_i'\sim\mathcal{P}$ 独立于 $S,U$，并以 $S^{(i)}$ 表示用 $z_i'$ 替换 $z_i$ 所得样本。定义

$$
\begin{aligned}
R_{\mathcal{P}}(w)&=\mathbb{E}_{z\sim\mathcal{P}}\ell(w,z),\\
\hat{R}_S(w)&=\frac{1}{n}\sum_{i=1}^{n}\ell(w,z_i),\\
\gamma_n(A_n,\mathcal{P})&=\frac{1}{n}\sum_{i=1}^{n}\mathbb{E}\big[\ell(A_n(S^{(i)},U),z_i)-\ell(A_n(S,U),z_i)\big].
\end{aligned}
$$

则该问题分布无关 PAC 可学习，也就是存在随机算法 $(B_n)$，使任意 $\varepsilon,\delta\in(0,1)$ 都有不依赖 $\mathcal{P}$ 的 $n_0$，且所有 $n\ge n_0$ 均满足

$$
\mathbb{P}_{S,U}\Big\{R_{\mathcal{P}}(B_n(S,U))-\inf_{w\in\mathcal{W}}R_{\mathcal{P}}(w)\le\varepsilon\Big\}\ge 1-\delta,
$$

当且仅当存在随机算法 $(A_n)$ 以及不依赖 $\mathcal{P}$ 的非负序列 $\rho_n\to 0$、$\bar{\beta}_n\to 0$，使每份 $s\in Z^n$ 都满足

$$
\mathbb{E}_U\hat{R}_s(A_n(s,U))-\inf_{w\in\mathcal{W}}\hat{R}_s(w)\le\rho_n,
$$

并且每个 $Z$ 上的概率分布 $\mathcal{P}$ 都满足

$$
\gamma_n(A_n,\mathcal{P})\le\bar{\beta}_n.
$$

**证明** 充分性由定理 7.15与定理 7.4给出。对于必要性，前面的基本定理保证可学习问题存在均匀稳定的始终 AERM 算法；均匀稳定性又蕴含平均稳定性，因此同一个算法满足这里的条件。 ■

等价刻画允许选择不同算法。固定某个算法以后，平均稳定性仍不能升级为均匀稳定性，平均的一侧保证也不能升级为逐样本保证。

### 7.3.4 参数稳定性

正则化和梯度下降的分析通常先得到两次输出参数的距离，随后才能估计损失差。**参数稳定性**（argument stability，也称 model stability）直接控制这个距离。本小节令 $\mathcal{W}\subseteq\mathbb{R}^d$，用欧氏范数度量参数向量；换一种参数表示或距离，条件本身也会改变。平均参数稳定性可以用于优化算法的精细泛化分析[7]。

[7] Y. Lei, Y. Ying, *Fine-Grained Analysis of Stability and Generalization for Stochastic Gradient Descent* In Proceedings of the 37th International Conference on Machine Learning, 2020, pp. 5809–5819

**定义 7.17　均匀参数稳定性**　设算法 $A(S,U)\in\mathcal{W}\subseteq\mathbb{R}^d$。若对任意相邻样本 $S,S'$ 都有

$$\mathbb{E}_U\|A(S,U)-A(S',U)\|_2\le\alpha_n,$$

则称算法具有速率 $\alpha_n$ 的均匀参数稳定性。两次运行使用相同的内部随机数 $U$。

**定义 7.18　平均参数稳定性**　沿用定义 7.14中的 $S,S^{(i)}$ 和 $U$。若

$$\frac{1}{n}\sum_{i=1}^{n}\mathbb{E}_{S,z_i',U}\|A(S,U)-A(S^{(i)},U)\|_2\le\bar{\alpha}_n(\mathcal{P}),\tag{7.7}$$

则称算法在分布 $\mathcal{P}$ 下具有速率 $\bar{\alpha}_n(\mathcal{P})$ 的平均参数稳定性。若同一个上界适用于所有允许分布，则称其为分布无关平均参数稳定性。

共享 $U$ 是为了固定算法自身的随机变化。例如，比较两次 SGD 时采用相同初始化和索引序列，输出差才反映样本替换。若独立采样内部随机数，即使样本相同也可能得到不同输出。均匀参数稳定性对每对相邻样本都控制这一距离；平均参数稳定性则按照 $\mathcal{P}$ 下样本出现的概率平均。

样本均值提供了参数距离的直接计算：替换一项后，$A(S^{(i)})-A(S)=(z_i'-z_i)/n$。在 $[0,1]$ 上，均匀界为 $1/n$，平均界则为 $\mathbb{E}|z-z'|/n$。若 $z$ 以概率 $p$ 取 1、其余取 0，两次独立取值不同的概率是 $2p(1-p)$，故平均界为 $2p(1-p)/n$。当数据几乎恒定时，这一平均距离可以比最坏情形距离小得多。

参数距离进入风险分析，还需要把它转换为损失变化。若存在同一个 $L$，使任意 $\boldsymbol{u},\boldsymbol{v}\in\mathcal{W}$ 和 $z\in Z$ 满足

$$|\ell(\boldsymbol{u},z)-\ell(\boldsymbol{v},z)|\le L\|\boldsymbol{u}-\boldsymbol{v}\|_2,\tag{7.8}$$

则称损失关于参数为 $L$-Lipschitz。这个条件保证参数移动 $r$ 时，每个观测的损失最多变化 $Lr$，因此可以把参数稳定性接到前面的损失稳定性定理。

**定理 7.19　参数稳定性与损失稳定性**　设 $(Z,\mathcal{Z})$ 为可测观测空间，$\mathcal{W}\subseteq\mathbb{R}^d$ 配备 Borel $\sigma$ 代数，$\ell:\mathcal{W}\times Z\to\mathbb{R}$ 可测，并且对任意 $\boldsymbol{u},\boldsymbol{v}\in\mathcal{W}$ 及 $z\in Z$ 都有

$$|\ell(\boldsymbol{u},z)-\ell(\boldsymbol{v},z)|\le L\|\boldsymbol{u}-\boldsymbol{v}\|_2.$$

令可测算法 $A : Z^n \times \mathcal{U} \to \mathcal{W}$ 使用内部随机数 $U$；比较两份样本时，两次运行共享同一个 $U$。假定每个固定 $s \in Z^n, z \in Z$ 下，$\ell(A(s,U),z)$ 关于 $U$ 可积。若任意只相差一个观测的 $s, s' \in Z^n$ 均满足

$$\mathbb{E}_U \|A(s,U) - A(s',U)\|_2 \le \alpha_n,$$

则任意这样的 $s, s'$ 及任意 $z \in Z$ 均满足

$$\left|\mathbb{E}_U \ell(A(s,U),z) - \mathbb{E}_U \ell(A(s',U),z)\right| \le L\alpha_n.$$

另一方面，固定 $Z$ 上的概率分布 $\mathcal{P}$，令 $S = (z_1, \dots, z_n) \sim \mathcal{P}^n$，令 $z_i' \sim \mathcal{P}$ 独立于 $S, U$，并以 $S^{(i)}$ 表示用 $z_i'$ 替换 $z_i$ 所得的样本。假定 $\ell(A(S,U),z_i)$ 与 $\ell(A(S^{(i)},U),z_i)$ 均可积。若

$$\frac{1}{n}\sum_{i=1}^{n} \mathbb{E}_{S,z_i',U} \|A(S,U) - A(S^{(i)},U)\|_2 \le \bar{\alpha}_n(\mathcal{P}),$$

则

$$\frac{1}{n}\sum_{i=1}^{n} \mathbb{E}_{S,z_i',U}[\ell(A(S^{(i)},U),z_i) - \ell(A(S,U),z_i)] \le L\bar{\alpha}_n(\mathcal{P}).$$

**证明**　对任意相邻样本和任意观测，Lipschitz 条件给出

$$\left|\mathbb{E}_U \ell(A(S,U),z) - \mathbb{E}_U \ell(A(S',U),z)\right| \le L\mathbb{E}_U \|A(S,U) - A(S',U)\|_2.$$

代入均匀参数稳定性上界得到第一项结论。对于平均稳定性，对定义 7.14中的损失差逐项取绝对值，再使用 Lipschitz 条件，得到

$$|\gamma_n(A,\mathcal{P})| \le \frac{L}{n}\sum_{i=1}^{n} \mathbb{E}_{S,z_i',U} \|A(S^{(i)},U) - A(S,U)\|_2 \le L\bar{\alpha}_n(\mathcal{P}).$$

这也给出了平均稳定性所需的一侧上界。 ■

完成这一转换后，参数化算法也能使用替换样本恒等式。这里仍须分清单次训练的泛化差 $R_{\mathcal{P}}(A(S,U)) - \hat{R}_S(A(S,U))$，与对 $S, U$ 平均后的期望泛化差。平均参数距离直接约束的是后者，说明经验评价的平均偏差有多大。

**定理 7.20　参数稳定性与期望泛化差**　设 $(Z,\mathcal{Z})$ 为可测观测空间，$\mathcal{W}\subseteq\mathbb{R}^d$ 配备 Borel $\sigma$ 代数，$\ell:\mathcal{W}\times Z\to\mathbb{R}$ 可测，并且对任意 $\boldsymbol{u},\boldsymbol{v}\in\mathcal{W}$ 及 $z\in Z$ 都有

$$|\ell(\boldsymbol{u},z)-\ell(\boldsymbol{v},z)|\le L\|\boldsymbol{u}-\boldsymbol{v}\|_2.$$

固定 $Z$ 上的概率分布 $\mathcal{P}$，令 $S=(z_1,\dots,z_n)\sim\mathcal{P}^n$，令算法内部随机数 $U$ 独立于 $S$，并令可测算法 $A:Z^n\times\mathcal{U}\to\mathcal{W}$ 输出 $A(S,U)$。令 $z_i'\sim\mathcal{P}$ 独立于 $S,U$，并以 $S^{(i)}$ 表示用 $z_i'$ 替换 $z_i$ 所得的样本；再令 $z\sim\mathcal{P}$ 独立于 $S,U,z_i'$。定义

$$R_{\mathcal{P}}(w)=\mathbb{E}_{z\sim\mathcal{P}}\ell(w,z),\qquad \hat{R}_S(w)=\frac{1}{n}\sum_{i=1}^{n}\ell(w,z_i).$$

假定独立测试损失 $\ell(A(S,U),z)$、训练损失 $\ell(A(S,U),z_i)$ 和替换损失 $\ell(A(S^{(i)},U),z_i)$ 均可积。若

$$\frac{1}{n}\sum_{i=1}^{n}\mathbb{E}_{S,z_i',U}\|A(S,U)-A(S^{(i)},U)\|_2\le\bar{\alpha}_n(\mathcal{P}),$$

则

$$\left|\mathbb{E}_{S,U}[R_{\mathcal{P}}(A(S,U))-\hat{R}_S(A(S,U))]\right|\le L\bar{\alpha}_n(\mathcal{P}).\tag{7.9}$$

特别地，期望风险满足

$$\mathbb{E}_{S,U}R_{\mathcal{P}}(A(S,U))\le\mathbb{E}_{S,U}\hat{R}_S(A(S,U))+L\bar{\alpha}_n(\mathcal{P}).$$

若任意只相差一个观测的 $s,s'\in Z^n$ 都满足 $\mathbb{E}_U\|A(s,U)-A(s',U)\|_2\le\alpha_n$，则可将两式中的 $\bar{\alpha}_n(\mathcal{P})$ 替换为 $\alpha_n$。

**证明**　替换样本恒等式 (7.5)给出

$$\mathbb{E}_{S,U}[R_{\mathcal{P}}(A(S,U))-\hat{R}_S(A(S,U))]=\gamma_n(A,\mathcal{P}).$$

前一定理的证明已经得到 $|\gamma_n(A,\mathcal{P})|\le L\bar{\alpha}_n(\mathcal{P})$，故第一式成立。取其上侧不等式，并把平均经验风险移到右侧，即得第二式。均匀参数稳定性对每对相邻样本都成立，对这些样本取平均后仍成立，故可取 $\bar{\alpha}_n(\mathcal{P})\le\alpha_n$。 ■

上界先平均泛化差再取绝对值，因此正负偏差仍可抵消。$L\bar{\alpha}_n(\mathcal{P})$ 不能直接用于某一次训练的绝对泛化差。若要在一份样本上由经验风险估计期望风险，可以加强为均匀参数稳定性，并限制损失的取值范围。

**定理 7.21　均匀参数稳定性的高概率泛化界**　设 $(Z, \mathcal{Z})$ 为可测观测空间，$\mathcal{W} \subseteq \mathbb{R}^d$ 配备 Borel $\sigma$ 代数，$\ell : \mathcal{W} \times Z \to [0,1]$ 可测，并且对任意 $\boldsymbol{u}, \boldsymbol{v} \in \mathcal{W}$ 及 $z \in Z$ 都有

$$|\ell(\boldsymbol{u}, z) - \ell(\boldsymbol{v}, z)| \le L\|\boldsymbol{u} - \boldsymbol{v}\|_2.$$

固定 $Z$ 上的概率分布 $\mathcal{P}$，令 $S = (z_1, \dots, z_n) \sim \mathcal{P}^n$，并令确定性可测算法 $A : Z^n \to \mathcal{W}$ 满足

$$\|A(s) - A(s')\|_2 \le \alpha_n$$

对任意只相差一个观测的 $s, s' \in Z^n$ 成立。定义

$$R_{\mathcal{P}}(w) = \mathbb{E}_{z\sim\mathcal{P}}\ell(w, z), \qquad \hat{R}_S(w) = \frac{1}{n}\sum_{i=1}^{n}\ell(w, z_i).$$

对任意 $\delta \in (0,1)$，以至少 $1-\delta$ 的样本概率，有

$$|R_{\mathcal{P}}(A(S)) - \hat{R}_S(A(S))| \le L\alpha_n + (2nL\alpha_n + 1)\sqrt{\frac{\log(2/\delta)}{2n}}.$$

**证明**　由定理 7.19，该算法具有 $L\alpha_n$ 均匀稳定性。将 $\beta_n = L\alpha_n$ 代入定理 7.11即得结论。 ■

$L$ 固定且 $\alpha_n = O(1/n)$ 时，所列高概率界趋于零。仅有 $\alpha_n \to 0$ 却不足以保证该式下降，较慢的速率可能需要前面的精细集中结果。定义 7.17对随机算法只平均内部随机数，因而能够分析内部随机性平均后的损失；单次随机输出还需另外控制。

参数稳定不保证算法选择了低风险决策。取 $[0,1]$ 上的平方损失，让算法始终输出 0，它的参数变化为零；若观测恒为 1，训练和测试风险却都为 1，而决策 1 的期望风险为零。泛化差虽为零，算法仍远离最优。为排除这种情形，学习保证还必须约束经验优化误差。

**定理 7.22　参数稳定性与可学习性**　设 $(Z, \mathcal{Z})$ 为可测观测空间，$\mathcal{W} \subseteq \mathbb{R}^d$ 为非空 Borel 决策空间，$\ell : \mathcal{W} \times Z \to \mathbb{R}$ 可测，并且对任意 $\boldsymbol{u}, \boldsymbol{v} \in \mathcal{W}$ 及 $z \in Z$ 都有

$$|\ell(\boldsymbol{u}, z) - \ell(\boldsymbol{v}, z)| \le L\|\boldsymbol{u} - \boldsymbol{v}\|_2,$$

其中 $L$ 不依赖分布或样本量。对每个允许分布 $\mathcal{P}$，令 $S=(z_1,\dots,z_n)\sim\mathcal{P}^n$，令算法内部随机数 $U$ 独立于 $S$，并令可测算法 $A: Z^n\times\mathcal{U}\to\mathcal{W}$ 输出 $A(S,U)$。令 $z_i'\sim\mathcal{P}$ 独立于 $S,U$，并以 $S^{(i)}$ 表示用 $z_i'$ 替换 $z_i$ 所得的样本；再令 $z\sim\mathcal{P}$ 独立于 $S,U,z_i'$。定义

$$R_{\mathcal{P}}(\boldsymbol{w})=\mathbb{E}_{z\sim\mathcal{P}}\ell(\boldsymbol{w},z),\qquad \hat{R}_S(\boldsymbol{w})=\frac{1}{n}\sum_{i=1}^{n}\ell(\boldsymbol{w},z_i).$$

假定独立测试损失、训练损失、替换损失以及每个固定 $\boldsymbol{w}\in\mathcal{W}$ 的 $\ell(\boldsymbol{w},z)$ 均可积；出现的经验风险和期望风险下确界为有限实数且可测。若存在不依赖 $\mathcal{P}$ 的非负数 $\bar{\alpha}_n,\rho_n$，使

$$\frac{1}{n}\sum_{i=1}^{n}\mathbb{E}_{S,z_i',U}\|A(S,U)-A(S^{(i)},U)\|_2\le\bar{\alpha}_n$$

并且

$$\mathbb{E}_{S,U}\left[\hat{R}_S(A(S,U))-\inf_{\boldsymbol{w}\in\mathcal{W}}\hat{R}_S(\boldsymbol{w})\right]\le\rho_n,$$

其中 $\bar{\alpha}_n,\rho_n$ 均不依赖分布，则

$$\mathbb{E}_{S,U}R_{\mathcal{P}}(A(S,U))-\inf_{\boldsymbol{w}\in\mathcal{W}}R_{\mathcal{P}}(\boldsymbol{w})\le L\bar{\alpha}_n+\rho_n.$$

若 $\bar{\alpha}_n\to0$ 且 $\rho_n\to0$，则算法分布无关 PAC 学习此问题。具体地，$L\bar{\alpha}_n+\rho_n\le\varepsilon\delta$ 是达到精度 $\varepsilon$ 与置信度 $1-\delta$ 的充分样本量条件。若任意只相差一个观测的 $s,s'\in Z^n$ 都满足 $\mathbb{E}_U\|A(s,U)-A(s',U)\|_2\le\alpha_n$，则可用 $\alpha_n$ 替换 $\bar{\alpha}_n$。

**证明** 定理 7.20给出 $g_n=L\bar{\alpha}_n$ 的期望泛化差上界。将它与题设的经验优化误差代入定理 7.4即得全部结论。 ■

本定理通过非负超额期望风险完成概率转换，与前一个高概率泛化界的集中证明不同。因此，只要此处两项代价趋于零，就能得到学习保证，无须先证明前一个高概率界下降。固定分布下的两项上界只给出该分布的结论，分布无关结论则要求统一速率。

继续取 Bernoulli 观测：$z$ 以概率 $p$ 为 1，其余为 0，$\mathcal{W}=[0,1]$，用平方损失评价样本均值。这里 $L=2$、$\bar{\alpha}_n(\mathcal{P})=2p(1-p)/n$，且均值为经验最优解，故 $\rho_n=0$。将它们分别代入定理 7.20与定理 7.22，得到

$$\left|\mathbb{E}[R_{\mathcal{P}}(\bar{z})-\hat{R}_S(\bar{z})]\right|\le\frac{4p(1-p)}{n},$$
$$\mathbb{E}R_{\mathcal{P}}(\bar{z})-\inf_{w\in[0,1]}R_{\mathcal{P}}(w)\le\frac{4p(1-p)}{n}.$$

相同右侧在第一式约束经验与总体评价的偏差，在第二式约束输出与最优决策的差。由 $p(1-p)\le 1/4$ 可取分布无关充分样本量 $n\ge 1/(\varepsilon\delta)$。这比直接平均损失变化得到的常数宽松，因为统一 Lipschitz 转换没有保留全部损失结构。

Lipschitz 条件不能从参数距离小自动得到。对 $h_w(x)=\mathbb{I}\{x\ge w\}$，将参数从 $-a$ 改为 $a$ 只移动 $2a$，但 $x=0,y=1$ 处的零一损失会由 0 跳为 1，对任意 $a>0$ 均如此。反向也不成立：若 $\ell((a,b),z)=(a-z)^2$，损失完全不使用 $b$，任意改变 $b$ 都不影响损失。参数稳定性因此依赖表示与距离，是一条充分分析路径，并非所有成功算法都必须满足的性质。

无界参数上的平方损失无法满足统一 Lipschitz 常数。我们可以改用光滑性，并加强为参数距离的均方根控制：

$$b_n^2(\mathcal{P})=\frac{1}{n}\sum_{i=1}^{n}\mathbb{E}_{S,z_i',U}\|A(S^{(i)},U)-A(S,U)\|_2^2.$$

这里 $b_n(\mathcal{P})$ 为均方根距离。由 Cauchy–Schwarz 不等式，式 (7.7)的平均距离不超过它。下面用这项更强的控制替代全局梯度上界。

**定理 7.23　光滑损失下参数稳定性与期望泛化差**　设 $(Z,\mathcal{Z})$ 为可测观测空间，$\mathcal{W}=\mathbb{R}^d$，$\ell:\mathbb{R}^d\times Z\to[0,\infty)$ 可测。对任意 $z$，$\ell(\cdot,z)$ 在 $\mathbb{R}^d$ 上可微且 $M$-光滑，其中 $M>0$，即

$$\|\nabla\ell(\boldsymbol{u},z)-\nabla\ell(\boldsymbol{v},z)\|_2\le M\|\boldsymbol{u}-\boldsymbol{v}\|_2.$$

固定 $Z$ 上的概率分布 $\mathcal{P}$，令 $S=(z_1,\dots,z_n)\sim\mathcal{P}^n$，令算法内部随机数 $U$ 独立于 $S$，并令可测算法 $A:Z^n\times\mathcal{U}\to\mathbb{R}^d$ 输出 $A(S,U)$。令 $z_i'\sim\mathcal{P}$ 独立于 $S,U$，并以 $S^{(i)}$ 表示用 $z_i'$ 替换 $z_i$ 所得的样本；再令 $z\sim\mathcal{P}$ 独立于 $S,U,z_i'$。定义

$$R_{\mathcal{P}}(\boldsymbol{w})=\mathbb{E}_{z\sim\mathcal{P}}\ell(\boldsymbol{w},z),\qquad \hat{R}_S(\boldsymbol{w})=\frac{1}{n}\sum_{i=1}^{n}\ell(\boldsymbol{w},z_i).$$

假定独立测试损失 $\ell(A(S,U),z)$、训练损失 $\ell(A(S,U),z_i)$ 和替换损失 $\ell(A(S^{(i)},U),z_i)$ 均可积。定义

$$b_n^2(\mathcal{P})=\frac{1}{n}\sum_{i=1}^{n}\mathbb{E}_{S,z_i',U}\|A(S^{(i)},U)-A(S,U)\|_2^2,$$

并假定 $b_n(\mathcal{P})<\infty$。记 $r_n=\mathbb{E}_{S,U}\hat{R}_S(A(S,U))<\infty$。则

$$\mathbb{E}_{S,U}[R_{\mathcal{P}}(A(S,U))-\hat{R}_S(A(S,U))]\le b_n(\mathcal{P})\sqrt{2Mr_n}+\frac{M}{2}b_n^2(\mathcal{P}).\tag{7.10}$$

**证明** 光滑性意味着对任意 $\boldsymbol{u},\boldsymbol{v}$ 都有

$$\ell(\boldsymbol{v},z)\le \ell(\boldsymbol{u},z)+\langle \nabla \ell(\boldsymbol{u},z),\boldsymbol{v}-\boldsymbol{u}\rangle+\frac{M}{2}\|\boldsymbol{v}-\boldsymbol{u}\|_2^2.$$

令 $\boldsymbol{v}=\boldsymbol{u}-\nabla\ell(\boldsymbol{u},z)/M$，并利用左侧非负，得到 $\|\nabla\ell(\boldsymbol{u},z)\|_2^2\le 2M\ell(\boldsymbol{u},z)$。再令 $\boldsymbol{u}=A(S,U)$、$\boldsymbol{v}=A(S^{(i)},U)$，对 $z_i$ 使用同一个光滑性不等式。对样本、替换观测、内部随机数和位置取平均，内积项至多为

$$\left(\frac{1}{n}\sum_i \mathbb{E}\|\nabla\ell(A(S,U),z_i)\|_2^2\right)^{1/2} b_n(\mathcal{P})\le \sqrt{2Mr_n}\,b_n(\mathcal{P}).$$

二次项平均为 $Mb_n^2(\mathcal{P})/2$。代入期望泛化差恒等式即得结论。 ■

所得界不要求凸性，用实际平均经验风险 $r_n$ 控制梯度大小。参数扰动不变时，较小的 $r_n$ 会减小右侧；若训练同时增大 $b_n(\mathcal{P})$，就必须计算二者的共同变化。单凭经验风险下降仍不能推出泛化改善。这是一侧期望泛化差上界，加上平均经验风险后可估计 $\mathbb{E}_{S,U}R_{\mathcal{P}}(A(S,U))$。要形成分布无关学习保证，还须统一控制均方根距离、平均经验风险和经验优化误差。

**定理 7.24 光滑损失下参数稳定性与可学习性** 设 $(Z,\mathcal{Z})$ 为可测观测空间，$\mathcal{W}=\mathbb{R}^d$，$\ell:\mathbb{R}^d\times Z\to[0,\infty)$ 可测。对任意 $z$，$\ell(\cdot,z)$ 在 $\mathbb{R}^d$ 上可微，且存在不依赖分布或样本量的 $M>0$ 使

$$\|\nabla\ell(\boldsymbol{u},z)-\nabla\ell(\boldsymbol{v},z)\|_2\le M\|\boldsymbol{u}-\boldsymbol{v}\|_2.$$

对每个允许分布 $\mathcal{P}$，令 $S=(z_1,\dots,z_n)\sim\mathcal{P}^n$，令算法内部随机数 $U$ 独立于 $S$，并令可测算法 $A:Z^n\times\mathcal{U}\to\mathbb{R}^d$ 输出 $A(S,U)$。令 $z_i'\sim\mathcal{P}$ 独立于 $S,U$，并以 $S^{(i)}$ 表示用 $z_i'$ 替换 $z_i$ 所得的样本；再令 $z\sim\mathcal{P}$ 独立于 $S,U,z_i'$。定义

$$R_{\mathcal{P}}(\boldsymbol{w})=\mathbb{E}_{z\sim\mathcal{P}}\ell(\boldsymbol{w},z),\qquad \hat{R}_S(\boldsymbol{w})=\frac{1}{n}\sum_{i=1}^n\ell(\boldsymbol{w},z_i).$$

假定独立测试损失、训练损失、替换损失以及每个固定 $\boldsymbol{w}\in\mathbb{R}^d$ 的 $\ell(\boldsymbol{w},z)$ 均可积；出现的经验风险和期望风险下确界为有限实数且可测。定义

$$b_n^2(\mathcal{P})=\frac{1}{n}\sum_{i=1}^n\mathbb{E}_{S,z_i',U}\|A(S^{(i)},U)-A(S,U)\|_2^2,$$

$$r_n=\mathbb{E}_{S,U}\hat{R}_S(A(S,U)).$$

若存在不依赖分布的非负序列 $b_n, c_n, \rho_n$，使所有允许分布均满足

$$b_n(\mathcal{P}) \le b_n, \qquad r_n \le c_n,$$
$$\mathbb{E}_{S,U}[\hat{R}_S(A(S,U)) - \inf_{\boldsymbol{w}\in\mathbb{R}^d} \hat{R}_S(\boldsymbol{w})] \le \rho_n,$$

则

$$\mathbb{E}_{S,U} R_{\mathcal{P}}(A(S,U)) - \inf_{\boldsymbol{w}\in\mathbb{R}^d} R_{\mathcal{P}}(\boldsymbol{w})$$
$$\le b_n\sqrt{2Mc_n} + \frac{M}{2}b_n^2 + \rho_n =: q_n.$$

若 $q_n \to 0$，则算法分布无关 PAC 学习此问题；$q_n \le \varepsilon\delta$ 是达到精度 $\varepsilon$ 与置信度 $1-\delta$ 的充分样本量条件。

**证明**　定理 7.23给出 $g_n = b_n\sqrt{2Mc_n} + Mb_n^2/2$ 的期望泛化差上界。将它与经验优化误差 $\rho_n$ 代入定理 7.4即得结论。 ■

例如，$M$ 固定且 $c_n \le C < \infty$ 时，$b_n \to 0$ 与 $\rho_n \to 0$ 便足以使 $q_n \to 0$。若 $c_n$ 增长，则还需 $b_n\sqrt{c_n} \to 0$。光滑性因此可以替代全局 Lipschitz 条件，但转换代价保留了损失大小。后面的正则化与 SGD 分析将先控制参数距离，再使用这些关系估计风险。

### 7.3.5 互信息稳定性

除了比较相邻样本，我们还可以直接考察输出对训练样本保留了多少信息。恒定输出不包含样本信息，逐字保存观测则保留全部样本。信息论量化两者之间的统计依赖，因而无需先给决策空间指定参数距离。这提供了分析同一个泛化问题的另一种入口。

数据参与选择后，经验评价会受到样本与输出之间依赖的影响。相对熵比较真实联合规律与消除依赖后的参照规律，互信息据此量化样本—输出依赖，换测度界则把这项依赖代价转为平均评价偏差。相对熵非负，仅在两分布相同时为零，但通常不对称，不能当作距离使用（可参考第一卷“概率分布”章的互信息定义及同章的“指数矩约束下的期望响应”一节）。Russo 与 Zou 用信息量控制自适应分析中的选择偏差[8]。Xu 与 Raginsky 进一步将样本—输出互信息用于期望泛化差[9]。

为了量化训练引入的依赖，记 $W = A(S,U)$，比较两个过程的分布。实际训练先抽样再计算输出，得到 $P_{S,W}$；参照过程分别从边缘分布抽取样本与输出，得到 $P_S \otimes P_W$。参照过程保留两者各自的分布，却消除依赖，所以当前互信息为

$$I(W;S) = D_{\mathrm{KL}}(P_{S,W} \| P_S \otimes P_W).$$

$I(W;S)=0$ 等价于输出与样本独立。学习需要利用样本，因此我们不要求这一值总为零，而要求它相对于样本量的增长足够慢，具体条件如下。

**定义 7.25　互信息稳定性**　设 $S\sim\mathcal{P}^n$，$W=A_n(S,U)$，$U$ 独立于 $S$。若存在不依赖 $\mathcal{P}$ 的非负序列 $\iota_n$，满足

$$I(W;S)\le\iota_n\quad\text{对所有允许分布成立},\qquad \frac{\iota_n}{n}\longrightarrow 0,$$

则称算法序列具有分布无关的互信息稳定性。

条件限制的是单位观测对应的信息量，而非总互信息必须消失。例如，$\iota_n$ 按 $\log n$ 增长仍满足 $\iota_n/n\to 0$。下面先用有界损失说明怎样转换为泛化差；次高斯损失可用相应指数矩条件作类似推导。

**定理 7.26　互信息与期望风险**　设 $(Z,\mathcal{Z})$ 与 $(\mathcal{W},\mathcal{B}_{\mathcal{W}})$ 为可测空间，$\ell:\mathcal{W}\times Z\to[0,1]$ 可测，$\mathcal{P}$ 为 $Z$ 上的概率分布。令 $S=(z_1,\dots,z_n)\sim\mathcal{P}^n$，令算法内部随机数 $U$ 独立于 $S$，并令可测算法 $A:Z^n\times\mathcal{U}\to\mathcal{W}$ 输出 $W=A(S,U)$。定义

$$R_{\mathcal{P}}(w)=\mathbb{E}_{z\sim\mathcal{P}}\ell(w,z),$$

$$\hat{R}_S(w)=\frac{1}{n}\sum_{i=1}^{n}\ell(w,z_i),$$

$$I(W;S)=D_{\mathrm{KL}}(P_{W,S}\|P_W\otimes P_S).$$

则

$$\left|\mathbb{E}[R_{\mathcal{P}}(W)-\hat{R}_S(W)]\right|\le\sqrt{\frac{I(W;S)}{2n}}.\tag{7.11}$$

因此，$\mathbb{E}R_{\mathcal{P}}(W)$ 不超过 $\mathbb{E}\hat{R}_S(W)+\sqrt{I(W;S)/(2n)}$。

**证明**　令 $P=P_{S,W}$、$Q=P_S\otimes P_W$，并记 $g(S,W)=R_{\mathcal{P}}(W)-\hat{R}_S(W)$。在 $Q$ 下，给定 $W$ 后，样本仍然独立同分布，所以 $\mathbb{E}_Q g=0$。损失位于 $[0,1]$，Hoeffding 引理给出

$$\log\mathbb{E}_Q e^{\lambda g}\le\frac{\lambda^2}{8n},\qquad\lambda\in\mathbb{R}.$$

若 $I(W;S)=\infty$，所述上界只是平凡界。以下设互信息有限，此时 $P\ll Q$；$g$ 有界，故在 $P$ 下可积，上面的指数矩也有限。对任意 $\lambda>0$，改变分布的代价可由相对熵控制：

$$\lambda\mathbb{E}_P g\le D_{\mathrm{KL}}(P\|Q)+\log\mathbb{E}_Q e^{\lambda g}.\tag{7.12}$$

这是对当前泛化差应用换测度期望界所得的关系（可参考第一卷“概率分布”章的换测度期望界）。因此 $\mathbb{E}_P g \le I(W;S)/\lambda + \lambda/(8n)$。对 $-g$ 作相同推导，再对 $\lambda$ 取最优值得到结论。互信息为零时取极限；互信息无穷时上界不提供有效保证。 ■

证明的参照过程让输出与样本独立，所以经验风险对期望风险无偏。真实训练引入依赖后，相对熵控制平均偏差增加的代价。这一比较仍然只约束期望泛化差，尚未给出单次训练的高概率误差界。

**定理 7.27　互信息稳定性与可学习性**　设 $(Z,\mathcal{Z})$ 与 $(\mathcal{W},\mathcal{B}_{\mathcal{W}})$ 为可测空间，$\mathcal{W}$ 非空，$\ell : \mathcal{W}\times Z \to [0,1]$ 可测。对每个允许分布 $\mathcal{P}$，令 $S=(z_1,\dots,z_n)\sim \mathcal{P}^n$，令算法内部随机数 $U$ 独立于 $S$，并令可测算法 $A : Z^n \times \mathcal{U} \to \mathcal{W}$ 输出 $W = A(S,U)$。定义

$$R_{\mathcal{P}}(w) = \mathbb{E}_{z\sim\mathcal{P}}\ell(w,z),$$

$$\hat{R}_S(w) = \frac{1}{n}\sum_{i=1}^{n}\ell(w,z_i),$$

$$I(W;S) = D_{\mathrm{KL}}(P_{W,S}\|P_W \otimes P_S),$$

并假定经验风险与期望风险的下确界为有限实数且可测。若存在不依赖 $\mathcal{P}$ 的非负数 $\iota_n,\rho_n$，使对所有允许分布都有

$$I(W;S)\le \iota_n, \qquad \mathbb{E}[\hat{R}_S(W) - \inf_{w\in\mathcal{W}}\hat{R}_S(w)] \le \rho_n,$$

则

$$\mathbb{E}R_{\mathcal{P}}(W) - \inf_{w\in\mathcal{W}} R_{\mathcal{P}}(w) \le \sqrt{\frac{\iota_n}{2n}} + \rho_n.$$

若 $\iota_n/n \to 0$ 且 $\rho_n \to 0$，算法分布无关 PAC 学习此问题。条件 $\sqrt{\iota_n/(2n)} + \rho_n \le \varepsilon\delta$ 足以保证 PAC 目标。

**证明**　定理 7.26给出 $g_n = \sqrt{\iota_n/(2n)}$ 的期望泛化差上界。将它与经验优化误差 $\rho_n$ 代入定理 7.4即得结论。 ■

若输出只能从预先给定的 $K$ 个决策中选择，互信息不超过输出熵 $H(W) = -\sum_{w}\mathbb{P}(W=w)\log\mathbb{P}(W=w)$，而输出熵不超过 $\log K$，因此可取 $\iota_n = \log K$。有限候选范围由此限制样本依赖。不过，恒定输出也满足 $I(W;S)=0$；它仍须取得小经验优化误差，才能接近最优风险。

整份样本的互信息把所有依赖合成一个数。若希望分别保留各观测的贡献，可以逐项比较输出与观测的依赖。Bu、Zou 与 Veeravalli 由此给出了下面的期望风险界[10]。

**定理 7.28　逐观测互信息的期望风险界**　设 $(Z, \mathcal{Z})$ 与 $(\mathcal{W}, \mathcal{B}_{\mathcal{W}})$ 为可测空间，$\ell : \mathcal{W} \times Z \to [0,1]$ 可测，$\mathcal{P}$ 为 $Z$ 上的概率分布。令 $S = (z_1, \dots, z_n) \sim \mathcal{P}^n$，令算法内部随机数 $U$ 独立于 $S$，并令可测算法 $A : Z^n \times \mathcal{U} \to \mathcal{W}$ 输出 $W = A(S, U)$。定义

$$R_{\mathcal{P}}(w) = \mathbb{E}_{z \sim \mathcal{P}} \ell(w, z),$$

$$\hat{R}_S(w) = \frac{1}{n} \sum_{i=1}^{n} \ell(w, z_i),$$

$$I(W; z_i) = D_{\mathrm{KL}}(P_{W, z_i} \| P_W \otimes \mathcal{P}).$$

则

$$\left| \mathbb{E}[R_{\mathcal{P}}(W) - \hat{R}_S(W)] \right| \le \frac{1}{n} \sum_{i=1}^{n} \sqrt{\frac{I(W; z_i)}{2}}.$$

**证明**　对每个 $i$，比较 $(W, z_i)$ 的联合分布与 $P_W \otimes \mathcal{P}$。在乘积分布下，$R_{\mathcal{P}}(W) - \ell(W, z_i)$ 的条件均值为零。沿用定理 7.26中样本量为 1 的指数矩论证，得到

$$\left| \mathbb{E}[R_{\mathcal{P}}(W) - \ell(W, z_i)] \right| \le \sqrt{I(W; z_i)/2}.$$

对 $n$ 项求和，再用三角不等式即可。 ■

将右侧逐观测信息代价记为 $\zeta_n(\mathcal{P})$，它与经验优化误差相加后给出 $\zeta_n(\mathcal{P}) + \rho_n(\mathcal{P})$ 的平均超额风险界。两项若都有分布无关且趋于零的上界，同样能够推出 PAC 学习。

普通互信息可能因连续输出的精确性而无穷。例如，在 $[0,1]$ 上均匀抽样并精确输出均值，平方损失下的期望泛化差为 $2\sigma^2/n$。但 $W$ 由 $S$ 确定，联合分布集中在 $W = \bar{z}$ 这一集合上，独立乘积分布却赋予该集合零概率，所以 $I(W; S) = \infty$。这个算法可以泛化，只是普通互信息界无法给出有效数值。

为避免记录连续观测的无限精度，Steinke 与 Zakynthinou 改为衡量选择信息[11]。先独立抽取 $n$ 对观测，每对随机选一个训练；在已知全部 $2n$ 个备选观测的条件下，只考察输出额外透露了哪一项被选中。每个位置的选择只有两个结果，因此连续观测不会自动使这项信息无穷。

[10] Y. Bu, S. Zou, V. V. Veeravalli, *Tightening Mutual Information-Based Bounds on Generalization Error* In IEEE Journal on Selected Areas in Information Theory, 2020, vol. 1, no. 1, pp. 121–130

[11] T. Steinke, L. Zakynthinou, *Reasoning About Generalization via Conditional Mutual Information* In Proceedings of the Thirty Third Conference on Learning Theory, 2020, pp. 3437–3452

给定备选观测后，我们比较输出与选择变量的条件联合分布和条件边缘乘积，再对备选观测平均 KL，得到两者的条件互信息。这里在标准 Borel 空间上使用这一条件核表述，以保证所需正则条件分布存在（可参考第一卷“概率分布”章的条件互信息定义）。

将这个过程写成随机变量：备选样本为 $\tilde{S} = ((z_{i,0}, z_{i,1}))_{i=1}^{n} \sim \mathcal{P}^{2n}$，独立选择变量 $\boldsymbol{B} = (B_1, \dots, B_n)$ 均匀取自 $\{0,1\}^n$。训练样本为 $S_{\boldsymbol{B}} = (z_{1,B_1}, \dots, z_{n,B_n})$。算法只访问选中的 $n$ 项，输出 $W = A(S_{\boldsymbol{B}}, U)$，且 $U$ 独立于 $\tilde{S}, \boldsymbol{B}$。图 7.2以三个观测对说明这一选择。

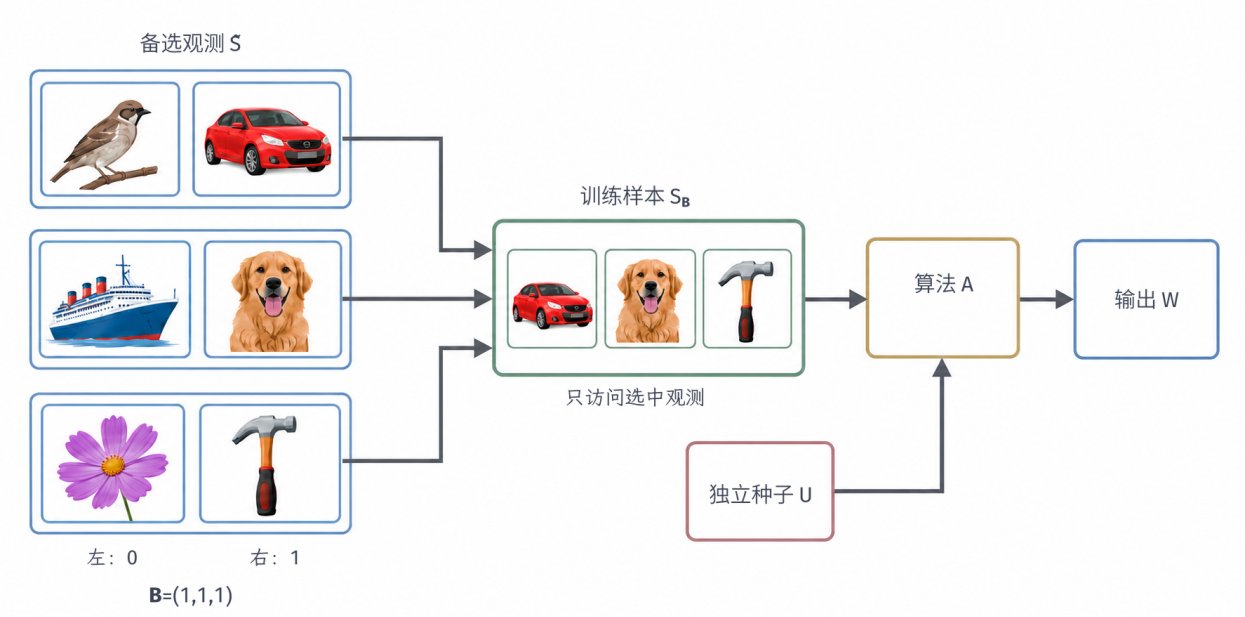


图 7.2　条件互信息的抽样构造。每行有两个独立观测，左、右分别编号 0、1；选择变量决定哪一个进入训练样本。图中 $\boldsymbol{B} = (1,1,1)$，箭头与训练集中的内容同时标出选中的观测。算法接收选中的三个观测与独立随机种子 $U$；条件互信息衡量已知全部六个观测时，输出对选择变量揭示了多少信息。

**定义 7.29　算法的条件互信息量**　在上述构造下，算法在分布 $\mathcal{P}$ 下的条件互信息量定义为

$$\kappa_n(A, \mathcal{P}) = I(W; \boldsymbol{B} \mid \tilde{S}).$$

若存在不依赖分布的 $\kappa_n$，使所有允许分布满足 $\kappa_n(A, \mathcal{P}) \le \kappa_n$ 且 $\kappa_n / n \to 0$，则称算法序列具有分布无关的条件互信息稳定性。

$\boldsymbol{B}$ 共有 $2^n$ 种取值，所以 $0 \le \kappa_n(A, \mathcal{P}) \le n \log 2$。这排除了连续输出导致的无穷值，却只给出与 $n$ 同阶的上界。要使泛化代价趋于零，还须证明实际揭示的选择信息为 $o(n)$。

**定理 7.30 条件互信息与期望风险** 设 $(Z,\mathcal{Z})$ 与 $(\mathcal{W},\mathcal{B}_{\mathcal{W}})$ 为标准 Borel 空间，$\ell:\mathcal{W}\times Z\to[0,1]$ 可测，$\mathcal{P}$ 为 $Z$ 上的概率分布。令 $\tilde{S}=((z_{i,0},z_{i,1}))_{i=1}^{n}\sim\mathcal{P}^{2n}$，令 $\boldsymbol{B}=(B_1,\dots,B_n)$ 独立于 $\tilde{S}$ 并均匀分布于 $\{0,1\}^n$，再令算法内部随机数 $U$ 独立于 $\tilde{S},\boldsymbol{B}$。定义训练样本 $S_{\boldsymbol{B}}=(z_{1,B_1},\dots,z_{n,B_n})$，并令可测算法 $A:Z^n\times\mathcal{U}\to\mathcal{W}$ 输出 $W=A(S_{\boldsymbol{B}},U)$。此时 $S_{\boldsymbol{B}}\sim\mathcal{P}^n$，且 $U$ 独立于 $S_{\boldsymbol{B}}$。定义

$$R_{\mathcal{P}}(w)=\mathbb{E}_{z\sim\mathcal{P}}\ell(w,z),$$

$$\hat{R}_{S_{\boldsymbol{B}}}(w)=\frac{1}{n}\sum_{i=1}^{n}\ell(w,z_{i,B_i}),$$

$$\kappa_n(A,\mathcal{P})=I(W;\boldsymbol{B}\mid\tilde{S}).$$

则

$$\left|\mathbb{E}[R_{\mathcal{P}}(W)-\hat{R}_{S_{\boldsymbol{B}}}(W)]\right|\le\sqrt{\frac{2\kappa_n(A,\mathcal{P})}{n}}.$$

**证明** 用每对中未被选中的观测评价输出，并减去经验风险，记

$$g(\tilde{S},\boldsymbol{B},W)=\frac{1}{n}\sum_{i=1}^{n}[\ell(W,z_{i,1-B_i})-\ell(W,z_{i,B_i})].$$

在真实联合分布 $P$ 下，未选观测独立于训练样本和算法内部随机数，所以 $\mathbb{E}_P g=\mathbb{E}[R_{\mathcal{P}}(W)-\hat{R}_{S_{\boldsymbol{B}}}(W)]$。构造参照分布 $Q$：保留 $(\tilde{S},W)$ 的联合分布，但在给定 $\tilde{S}$ 后独立、均匀地重新抽取 $\boldsymbol{B}$。于是 $D_{\mathrm{KL}}(P\|Q)=\kappa_n(A,\mathcal{P})$。

在 $Q$ 下，给定 $\tilde{S},W$，每一对的损失差随 $B_i$ 以相同概率取正负两个值，且绝对值不超过 1。各项独立，因此 $\log\mathbb{E}_Q e^{\lambda g}\le\lambda^2/(2n)$。将此式用于式 (7.12)，对正负两个方向分别取最优 $\lambda$，得到结论。 ■

如果固定 $\mathcal{P}$ 下的平均经验优化误差至多 $\rho_n(\mathcal{P})$，风险分解给出 $\sqrt{2\kappa_n(A,\mathcal{P})/n}+\rho_n(\mathcal{P})$ 的平均超额风险界。若存在分布无关上界 $\kappa_n,\rho_n$，且 $\kappa_n/n\to0$、$\rho_n\to0$，定理 7.4便给出 PAC 学习，充分条件为 $\sqrt{2\kappa_n/n}+\rho_n\le\varepsilon\delta$。条件互信息采用的参照过程不同于普通互信息，因此不能仅换掉 $I(W;S)$ 而照搬常数。它也可与始终 AERM 结合，刻画学习算法的存在性。

**定理 7.31 条件互信息稳定性与可学习性** 设 $(Z,\mathcal{Z})$ 与 $(\mathcal{W},\mathcal{B}_{\mathcal{W}})$ 为标准 Borel 空间，$\mathcal{W}$ 非空，$\ell:\mathcal{W}\times Z\to[0,1]$ 可测，并允许 $Z$ 上的所有概率分布。对每个 $n$，假定 $s\mapsto\inf_{w\in\mathcal{W}}n^{-1}\sum_{i=1}^{n}\ell(w,z_i)$ 可测；

随机算法均由可测映射 $A_n : Z^n \times \mathcal{U} \to \mathcal{W}$ 表示，其内部随机数 $U$ 与全部观测独立。定义

$$R_{\mathcal{P}}(w) = \mathbb{E}_{z\sim\mathcal{P}}\ell(w,z), \qquad \hat{R}_S(w) = \frac{1}{n}\sum_{i=1}^{n}\ell(w,z_i).$$

对每个 $\mathcal{P}$，再令 $\tilde{S} = ((z_{i,0}, z_{i,1}))_{i=1}^{n} \sim \mathcal{P}^{2n}$，令 $\boldsymbol{B} = (B_1,\dots,B_n)$ 独立于 $\tilde{S}, U$ 并均匀分布于 $\{0,1\}^n$，定义 $S_{\boldsymbol{B}} = (z_{1,B_1},\dots,z_{n,B_n})$；于是 $S_{\boldsymbol{B}} \sim \mathcal{P}^n$ 且 $U$ 独立于 $S_{\boldsymbol{B}}$。再定义

$$\kappa_n(A_n,\mathcal{P}) = I(A_n(S_{\boldsymbol{B}},U);\boldsymbol{B}\mid\tilde{S}).$$

则该问题分布无关 PAC 可学习，也就是存在随机算法 $(B_n)$，使任意 $\varepsilon,\delta\in(0,1)$ 都有不依赖 $\mathcal{P}$ 的 $n_0$，且所有 $n \ge n_0$ 均满足

$$\mathbb{P}_{S,U}\Big\{R_{\mathcal{P}}(B_n(S,U)) - \inf_{w\in\mathcal{W}} R_{\mathcal{P}}(w) \le \varepsilon\Big\} \ge 1-\delta,$$

当且仅当存在随机算法 $(A_n)$ 以及不依赖 $\mathcal{P}$ 的非负序列 $\rho_n \to 0$、$\kappa_n/n \to 0$，使每份 $s\in Z^n$ 都满足

$$\mathbb{E}_U\hat{R}_s(A_n(s,U)) - \inf_{w\in\mathcal{W}}\hat{R}_s(w) \le \rho_n,$$

并且每个 $Z$ 上的概率分布 $\mathcal{P}$ 都满足

$$\kappa_n(A_n,\mathcal{P}) \le \kappa_n.$$

**证明**　充分性由定理 7.30与定理 7.4给出。为证必要性，使用一般学习基本定理证明中的构造：从 $n$ 个位置中有放回地随机抽取 $k = \lfloor\sqrt{n}\rfloor$ 个位置，再调用已有学习算法。该构造已经保证始终 AERM。

记抽样索引为 $J = (J_1,\dots,J_k)$,原学习算法的内部随机数为 $U_0$。在给定 $\tilde{S}, J, U_0$ 时，新算法的输出仅由被访问位置的选择变量 $(B_{J_1},\dots,B_{J_k})$ 决定。每个选择变量至多包含 $\log 2$ 的信息量，故

$$\begin{aligned} I(W;\boldsymbol{B}\mid\tilde{S}) &\le I(W,J,U_0;\boldsymbol{B}\mid\tilde{S}) \\ &= I(W;\boldsymbol{B}\mid\tilde{S},J,U_0) \le k\log 2. \end{aligned}$$

等式使用 $J, U_0$ 与 $\tilde{S}, \boldsymbol{B}$ 独立；最后一步使用互信息不超过决定输出的离散选择变量的熵。因此可取 $\kappa_n = k\log 2$，并有 $\kappa_n/n \to 0$。 ■

这里仍然允许重新构造算法，并非要求每个成功算法本身具有小条件互信息。也不能将条件互信息换成普通互信息，因为后者会保留连续观测的无限精度。

### 7.3.6 稳定性的关系与边界

现在可以在同一泛化问题下比较这些条件。它们改变了扰动单位、比较对象和平均方式，所以名称相近并不保证相互蕴含。各条件只有在相应损失和概率假设下，才能提供与经验优化误差相加的风险代价。

固定替换操作，均匀损失界能够推出平均损失界；再加统一 Lipschitz 条件，均匀或平均参数界分别转换为对应损失界。删除改变样本量，不能沿用这条转换而直接等同替换。参数距离也必须先通过损失条件转换，不能跳过这一连接。

互信息与损失稳定性没有一般强弱排序。连续均值算法有趋于零的均匀稳定性，但普通互信息无穷。另一个方向可取 $z_i \in \{0,1\}$ 的二值观测：算法只在全 1 样本上输出 $W=1$，其余输出 0，损失为 $\ell(w,z)=w$。输出熵给出 $I(W;S)\le \log 2$，但替换全 1 样本的一项就使损失改变 1，均匀稳定性常数无法下降。信息代价小控制的是平均依赖，不控制每对相邻样本。

这个二值例子也说明泛化控制与学习目标的区别。观测恒为 1 时，算法始终输出 1，风险为 1，而决策 0 的风险为零；信息量虽小，经验最优性却失败。恒定输出同样可能满足多种稳定性而选择高风险决策，所以学习必须同时比较经验最优值。

定理 7.13、定理 7.16与定理 7.31分别用均匀、平均和条件互信息稳定的始终 AERM 算法刻画可学习性。这些结论讨论存在性；留一法、参数稳定性及普通互信息则提供另外的充分验证路径。它们都不能转成每个成功算法的必要性质。表 7.1列出直接控制的对象，图 7.3比较它们与一致收敛共享的证明目标。

| 条件 | 数据扰动 | 直接比较对象 | 平均或最坏情形 | 进入学习保证还需什么 |
|---|---|---|---|---|
| 留一法稳定性 | 删除一项 | 被删观测上的损失 | 对样本和位置平均 | 经验最优性；注意 $n$ 与 $n-1$ 的算法错位 |
| 均匀稳定性 | 替换一项 | 任意测试观测上的损失差 | 对相邻样本和测试观测取最坏情形 | 经验最优性；高概率界还需损失有界 |
| 平均稳定性 | 替换一项 | 被替换出的 $z_i$ 上的有符号损失差 | 对样本、位置、替换值和随机性平均 | 分布无关速率与经验最优性 |
| 参数稳定性 | 替换一项 | 共享随机数下的参数距离 | 可取最坏情形或平均 | 损失关于参数的 Lipschitz 性，或非负光滑损失的自界关系 |
| 互信息稳定性 | 不显式构造邻样本 | $I(W;S)$ | 对训练样本和算法随机性定义的分布量 | 有界或次高斯损失，以及经验最优性 |
| 条件互信息稳定性 | 双样本逐位选择 | 已知双样本时输出揭示的选择信息 | 对双样本、选择位和随机性定义的分布量 | 有界损失；可学习性刻画还需始终 AERM |

表 7.1 各类稳定性及算法依赖条件的对象与保证接口。表中条件之间不存在未注明的一般强弱关系。

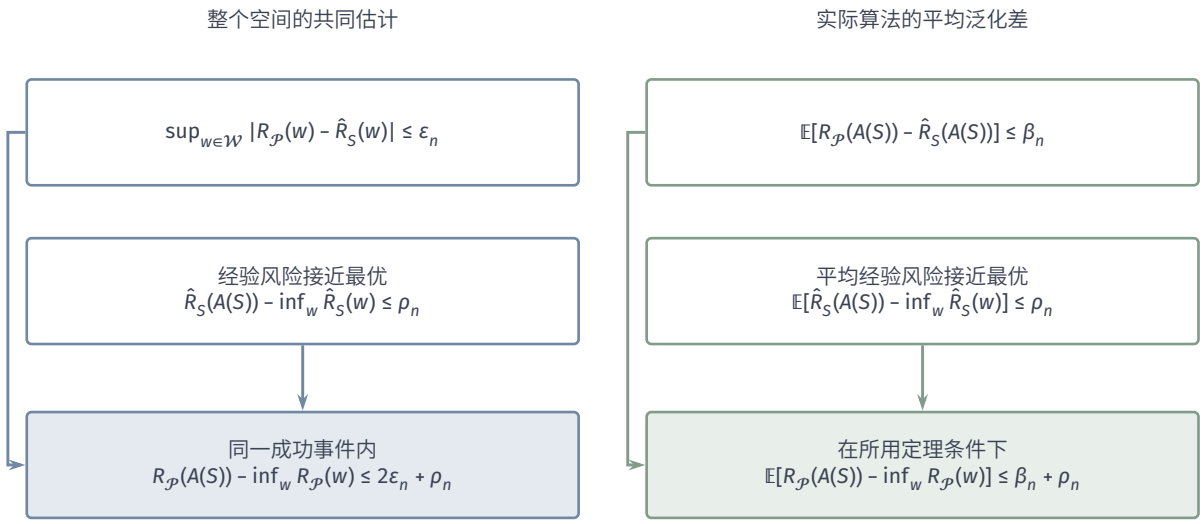


图 7.3　期望风险的两条分析路线。左侧同时控制整个决策空间，右侧控制算法输出的期望泛化差；两条路线都要结合经验最优性。右侧用 $\beta_n$ 泛指所选稳定性定理提供的代价项。

## 7.4 凸学习问题

为了得到具体学习算法，我们现在对决策空间和损失增加凸性。正则化给经验目标加入曲率，以控制最优解的移动；SGD 则逐步比较两条轨迹，再计算经验优化误差。凸性约束插值后的目标值，强凸性进一步使目标值差控制参数距离（可参考第一卷“最优化”章的凸集与凸函数定义与同章的相对于范数的强凸性定义）。

分析梯度更新时，光滑性给梯度变化上界；PL 条件用梯度大小控制目标误差，弱凸性则限制最坏负曲率（可参考第一卷“最优化”章的欧氏梯度光滑性定义、同章的 PL 条件定义与同章的欧氏弱凸性定义）。使用这些性质时，我们仍须在当前参数区域与范数下确认条件。例如，强凸惩罚可在不缩小原决策空间时稳定最优解，却也可能使经验风险偏离未正则化的最优值，二者必须一起计算。

### 7.4.1 凸性与损失函数

优化分类器时，我们需要知道分数改变是否降低损失。设真实标签为 $+1$，分数从 $-2$ 提高到 $-0.1$，零一损失仍为 1；它在零点跳变，在其余区域没有梯度变化，作为分数函数也不凸。将标签写为 $y \in \{-1, 1\}$ 后，线性分类可以采用合页损失 $\max\{0, 1 - y\boldsymbol{w}^{\top}\boldsymbol{x}\}$ 或逻辑损失 $\log(1 + e^{-y\boldsymbol{w}^{\top}\boldsymbol{x}})$。合页损失在这个例子中从 3 降到 1.1，分数达到 1 后才为零，因而同时要求正确预测和一定间隔。这些损失关于线性参数凸，便于求解，但改变了总体评价目标。**分类校准**（classification calibration）条件负责说明：替代风险趋于最优时，何时能够使零一风险也趋于最优。

校准考察固定输入下的标签选择。记 $\eta(x)=\mathbb{P}(y=1\mid x)$，按这个条件分布对替代损失取期望，得到条件替代风险。$\eta(x)>1/2$ 时，最优分数应选择正号；$\eta(x)<1/2$ 时应选择负号。例如，正标签概率为 0.7 时，预测正类错误率为 0.3，负类为 0.7，校准要求替代最优分数也偏好正号。凸性帮助求解，校准则联系不受限函数空间中的替代最优风险与贝叶斯风险。在受限线性类中，替代最优解未必也是零一最优解，还须检查近似能力。这里也区别于第 11.2.1节的概率校准：后者比较预测概率与事件频率，两者没有一般相互蕴含关系。

凸学习需要能够在两个决策之间插值，并约束插值后的损失。本节固定实赋范线性空间 $(V,\|\cdot\|)$，取 $\mathcal{W}\subseteq V$。除非另行改用欧氏空间，凸性、Lipschitz 性和强凸性都相对于这个空间及同一范数。

**定义 7.32　凸学习问题**　若 $\mathcal{W}$ 是凸集，并且对每个 $z\in Z$，函数 $w\mapsto \ell(w,z)$ 为凸函数，则称该一般学习问题为凸学习问题。也就是说，对任意 $u,v\in\mathcal{W}$、$t\in[0,1]$ 和 $z\in Z$，有

$$\ell(tu+(1-t)v,z)\le t\ell(u,z)+(1-t)\ell(v,z).$$

凸性说明插值损失与两端的关系，却没有限制相邻决策间损失变化的速度。要从参数距离控制损失差，还需要下面的变化率条件。

Lipschitz 常数给出统一变化率：若 $L=2$，决策移动 0.01，同一观测上的损失最多改变 0.02。

**定义 7.33　Lipschitz 损失**　若对任意 $w,w'$ 与 $z$ 都满足

$$|\ell(w,z)-\ell(w',z)|\le L\|w-w'\|, \tag{7.13}$$

则称损失关于该范数是 $L$-Lipschitz 的。

这里的凸性针对决策变量 $w$，损失对预测值凸并不使它对网络参数也凸。Hilbert 空间中的线性预测若满足 $\|\boldsymbol{w}\|\le B$、$\|\boldsymbol{x}\|\le r$，式 (5.15)给出 $Br/\sqrt{n}$ 量级的得分函数类复杂度。若标量损失为 $L$-Lipschitz，收缩引理进一步给出 $LBr/\sqrt{n}$ 量级的损失类复杂度；加入相应有界或次高斯条件后才能进入风险界。因此，应检查范数、损失和尾部条件，不能仅凭参数空间是否无限维判断。

### 7.4.2　凸学习问题的正则化

普通 ERM 可能在多个经验最优者之间跳动。为了限制样本替换造成的解移动，我们给目标加入正则项，取 $\lambda > 0$ 并令

$$A(S) \in \arg\min_{w \in \mathcal{W}} \left\{ \hat{R}_S(w) + \lambda \Omega(w) \right\}. \tag{7.14}$$

选择最小值仍是为了降低经验评价，但 $\Omega$ 同时规定额外代价。若整个目标 $F$ 满足

$$F(tu + (1-t)v) \le tF(u) + (1-t)F(v) - \frac{\mu}{2} t(1-t)\|u - v\|^2 \tag{7.15}$$

对所有可行 $u, v$ 与 $t \in [0,1]$ 成立，就称它为 $\mu$-强凸。减去的二次项排除平坦方向，让目标值变化能够控制解的距离。

普通凸目标可以有一段最小点，替换样本后可能选择这一段的另一端，而目标值几乎不变。强凸目标则使距离最小点为 $r$ 的决策至少付出与 $\mu r^2$ 同阶的代价。正则化引入的曲率因此限制了最优解的移动，作用不限于偏好小参数。

这个作用在均值估计中可显式计算。对 $z_i \in [0,1]$，最小化

$$\frac{1}{2n} \sum_{i=1}^{n} (w - z_i)^2 + \frac{\lambda}{2} w^2$$

得到 $\hat{w} = \bar{z}/(1+\lambda)$，替换一项最多改变 $1/[n(1+\lambda)]$。增大 $\lambda$ 缩小了变化，却把输出拉向零；总体均值远离零时便产生收缩偏差。下面不用显式解，而用强凸性和 Lipschitz 性证明一般上界。

**定理 7.34　强凸正则化的稳定性**　设 $(Z, \mathcal{Z})$ 为可测观测空间，$\mathcal{W}$ 是实赋范线性空间 $(V, \|\cdot\|)$ 中的非空凸 Borel 集，$\ell : \mathcal{W} \times Z \to \mathbb{R}$ 可测。对每个 $z \in Z$，函数 $\ell(\cdot, z)$ 在 $\mathcal{W}$ 上凸，并且对任意 $u, v \in \mathcal{W}$ 都有

$$|\ell(u, z) - \ell(v, z)| \le L \|u - v\|.$$

设 $\Omega : \mathcal{W} \to \mathbb{R}$ 可测，且对任意 $u, v \in \mathcal{W}$ 和 $t \in [0,1]$ 都有

$$\Omega(tu + (1-t)v) \le t\Omega(u) + (1-t)\Omega(v) - \frac{1}{2} t(1-t)\|u - v\|^2.$$

固定 $n \ge 1$ 与 $\lambda > 0$。对任意 $Z$ 上的概率分布 $\mathcal{P}$，训练样本满足 $S \sim \mathcal{P}^n$；对每份 $s = (z_1, \dots, z_n) \in Z^n$，定义

$$A(s) \in \arg\min_{w \in \mathcal{W}} \left\{ \frac{1}{n} \sum_{i=1}^{n} \ell(w, z_i) + \lambda \Omega(w) \right\},$$

并假定该最小解存在且 $A$ 可测。目标函数的强凸性使最小解唯一；对任意只相差一个观测的 $s, s' \in Z^n$ 及任意 $z \in Z$，算法满足

$$|\ell(A(s), z) - \ell(A(s'), z)| \le \beta_n,$$

并且其稳定性常数满足

$$\beta_n \le \frac{2L^2}{\lambda n} \tag{7.16}$$

**证明** 记相邻样本的解为 $w, w'$，相应正则目标为 $F_S, F_{S'}$。最优性和 $\lambda$-强凸性给出

$$F_S(w') - F_S(w) \ge \frac{\lambda}{2}\|w - w'\|^2, \quad F_{S'}(w) - F_{S'}(w') \ge \frac{\lambda}{2}\|w - w'\|^2.$$

相加后共同的 $n-1$ 个损失与正则项抵消，剩余两项由 Lipschitz 性至多为 $2L\|w - w'\|/n$。故 $\|w - w'\| \le 2L/(\lambda n)$。对任意测试观测 $z$，同一范数下的 Lipschitz 条件直接给出

$$|\ell(w, z) - \ell(w', z)| \le L\|w - w'\| \le \frac{2L^2}{\lambda n},$$

即得到所述均匀稳定性上界。 ■

增加 $\lambda$ 降低稳定性代价，却可能增加正则化偏差。岭回归采用 $\Omega(w) = \|w\|_2^2/2$，但平方损失不满足全局 Lipschitz 性。只有 $\|x\|$、$|y|$ 和 $\|w\|$ 受控、残差有界时，才能在当前区域给出有限 $L$，应用上述稳定性结论。

算法最小化的是经验风险与惩罚之和，因此未经正则化的经验最优性可能被牺牲。为了得到学习保证，我们接着比较这两种目标，并把牺牲量保留在风险上界中。

**定理 7.35 正则化学习的期望风险保证** 设 $(Z, \mathcal{Z})$ 为可测观测空间，$\mathcal{W}$ 是实赋范线性空间 $(V, \|\cdot\|)$ 中的非空凸 Borel 集，$\ell : \mathcal{W} \times Z \to \mathbb{R}$ 可测。对每个 $z \in Z$，函数 $\ell(\cdot, z)$ 在 $\mathcal{W}$ 上凸，并且对任意 $u, v \in \mathcal{W}$ 都有

$$|\ell(u, z) - \ell(v, z)| \le L\|u - v\|.$$

设 $\Omega : \mathcal{W} \to [0, \infty)$ 可测，且对任意 $u, v \in \mathcal{W}$ 和 $t \in [0, 1]$ 都有

$$\Omega(tu + (1-t)v) \le t\Omega(u) + (1-t)\Omega(v) - \frac{1}{2}t(1-t)\|u - v\|^2.$$

固定 $n \ge 1$ 与 $\lambda > 0$。令 $S = (z_1, \dots, z_n) \sim \mathcal{P}^n$，其中 $\mathcal{P}$ 为 $Z$ 上的概率分布，并定义可测算法

$$A(S) = \arg\min_{v \in \mathcal{W}} \left\{ \frac{1}{n} \sum_{i=1}^{n} \ell(v, z_i) + \lambda \Omega(v) \right\}.$$

再令 $z \sim \mathcal{P}$ 独立于 $S$，并定义

$$R_{\mathcal{P}}(w) = \mathbb{E}_{z \sim \mathcal{P}} \ell(w, z), \qquad \hat{R}_S(w) = \frac{1}{n} \sum_{i=1}^{n} \ell(w, z_i).$$

假定该最小解存在；独立测试损失 $\ell(A(S), z)$、训练损失 $\ell(A(S), z_i)$ 以及每个固定 $w \in \mathcal{W}$ 的 $\ell(w, z)$ 均可积。则对任意固定 $w \in \mathcal{W}$，

$$\mathbb{E}_S R_{\mathcal{P}}(A(S)) - R_{\mathcal{P}}(w) \le \frac{2L^2}{\lambda n} + \lambda \Omega(w). \tag{7.17}$$

若 $\mathcal{W}$ 为 Hilbert 空间中半径为 $B > 0$ 的闭球，$\Omega(w) = \|w\|^2/2$，且 $L > 0$，取 $\lambda = 2L/(B\sqrt{n})$ 可得

$$\mathbb{E}_S R_{\mathcal{P}}(A(S)) - \inf_{w \in \mathcal{W}} R_{\mathcal{P}}(w) \le \frac{2LB}{\sqrt{n}}.$$

**证明**　正则化目标的最优性给出

$$\hat{R}_S(A(S)) + \lambda \Omega(A(S)) \le \hat{R}_S(w) + \lambda \Omega(w).$$

去掉左侧非负的正则项，对样本取期望，再加上稳定性控制的期望泛化差，得到第一式。在半径 $B$ 的闭球上，$\Omega(w) \le B^2/2$。代入所给 $\lambda$ 后，稳定性项与正则化比较项均不超过 $LB/\sqrt{n}$。对 $w$ 取下确界得到第二式。 ■

风险界中的两项随 $\lambda$ 反向变化：稳定性代价下降，正则化比较项上升。比较项是偏差的上界，不是偏差精确值；平衡两个上界得到 $1/\sqrt{n}$ 的平均超额风险速率。输出属于比较空间，故超额风险非负，Markov 不等式给出 $n \ge (2LB/(\varepsilon\delta))^2$ 的 PAC 充分门槛。这一推导没有优化置信度依赖。

维度未显式进入这个界，是因为有限半径和 Lipschitz 常数已经限制了学习问题。它不包含无限 VC 维的无约束零一分类。采用平方损失时，也必须先核对数据与决策范围，使当前条件真正成立。

### 7.4.3 凸学习问题的随机梯度下降

逐步优化时，我们可以每次只使用一个训练观测的梯度，这就是随机梯度下降（stochastic gradient descent, SGD）。例如，$\ell(w,z)=(w-z)^2/2$ 的梯度为 $w-z$；从 $w=0.5$ 出发，步长 0.1，抽到 $z=0$ 得到 0.45，抽到 $z=1$ 得到 0.55。不同抽样顺序由此形成不同轨迹。例子只说明更新计算，下面的稳定性保证还需凸性、光滑性和 Lipschitz 性。

我们固定一份 $n$ 项样本，令各 $i_t$ 独立均匀取自 $\{1,\dots,n\}$，从确定初值迭代：

$$\boldsymbol{w}^{(t+1)}=\boldsymbol{w}^{(t)}-\eta_t\nabla\ell(\boldsymbol{w}^{(t)},z_{i_t}),\qquad t=0,\dots,T-1. \tag{7.18}$$

当前每个损失在欧氏空间上凸且 $L$-Lipschitz,并满足 $M$-光滑条件 $\|\nabla\ell(\boldsymbol{u},z)-\nabla\ell(\boldsymbol{v},z)\|_2\le M\|\boldsymbol{u}-\boldsymbol{v}\|_2$。索引选择让算法反复访问同一训练集，这正是这里要研究的数据依赖；若每步从总体抽取新观测，便属于另一个随机逼近问题。

**定理 7.36　凸光滑 SGD 的稳定性**　设 $(Z,\mathcal{Z})$ 为可测观测空间，$\ell:\mathbb{R}^d\times Z\to\mathbb{R}$ 可测。对每个 $z\in Z$，$\ell(\cdot,z)$ 可微、凸、$L$-Lipschitz 且 $M$-光滑，其中 $M>0$，即

$$|\ell(\boldsymbol{u},z)-\ell(\boldsymbol{v},z)|\le L\|\boldsymbol{u}-\boldsymbol{v}\|_2,$$
$$\|\nabla\ell(\boldsymbol{u},z)-\nabla\ell(\boldsymbol{v},z)\|_2\le M\|\boldsymbol{u}-\boldsymbol{v}\|_2,\qquad \boldsymbol{u},\boldsymbol{v}\in\mathbb{R}^d.$$

固定 $n,T\ge 1$、确定初值 $\boldsymbol{w}^{(0)}\in\mathbb{R}^d$ 以及步长 $0\le\eta_t\le 2/M$。任取 $Z$ 上的概率分布 $\mathcal{P}$ 并令 $S=(z_1,\dots,z_n)\sim\mathcal{P}^n$。算法内部随机数 $U=(i_0,\dots,i_{T-1})$ 独立于 $S$，并由独立且均匀分布于 $\{1,\dots,n\}$ 的索引组成；算法更新

$$\boldsymbol{w}^{(t+1)}=\boldsymbol{w}^{(t)}-\eta_t\nabla\ell(\boldsymbol{w}^{(t)},z_{i_t}),\qquad t=0,\dots,T-1.$$

令 $A_{n,T}(S,U)=\boldsymbol{w}^{(T)}$。比较相邻样本时，两次运行使用相同的初值和 $U$。则任意只相差一个观测的 $S,S'\in Z^n$ 及任意 $z\in Z$ 都满足

$$\left|\mathbb{E}_U\ell(A_{n,T}(S,U),z)-\mathbb{E}_U\ell(A_{n,T}(S',U),z)\right|\le\beta_n,$$

其中

$$\beta_n\le\frac{2L^2}{n}\sum_{t=0}^{T-1}\eta_t.$$

**证明**　在相邻样本上使用同一索引序列，可以逐步比较两条轨迹。凸光滑函数的梯度满足

$$\langle \nabla \ell(\boldsymbol{u}, z) - \nabla \ell(\boldsymbol{v}, z), \boldsymbol{u} - \boldsymbol{v} \rangle \geq \frac{1}{M} \|\nabla \ell(\boldsymbol{u}, z) - \nabla \ell(\boldsymbol{v}, z)\|_2^2 .$$

将一次梯度更新后的距离平方展开可知，当 $0 \leq \eta_t \leq 2/M$ 时，同一损失的梯度映射不扩大距离。因此，未抽中替换位置时，两条轨迹不会产生新的距离；抽中时，梯度范数至多 $L$，可用三角不等式把新增距离上界为 $2\eta_t L$。

令 $d_t = \mathbb{E}\|\boldsymbol{w}^{(t)} - \boldsymbol{w}'^{(t)}\|_2$，期望只对共同索引序列取。每步以 $1/n$ 的概率访问替换位置，因此 $d_{t+1} \leq d_t + 2\eta_t L/n$。从 $d_0 = 0$ 累加，再用 Lipschitz 性转换为损失差，得到

$$d_T \leq \frac{2L}{n} \sum_{t=0}^{T-1} \eta_t, \qquad \beta_n \leq \frac{2L^2}{n} \sum_{t=0}^{T-1} \eta_t . \tag{7.19}$$

■

轨迹距离界对每一对相邻样本成立，只平均索引随机性，因此首先验证均匀参数稳定性。乘上损失的 Lipschitz 常数后，再通过第 7.3节的结论控制期望泛化差。

式 (7.19)随总步长增长，而经验优化误差通常需要足够迭代才能降低。早停减小前一项，却可能增大后一项，所以停止时刻要按两项共同决定，不能由稳定性单独选出。Hardt、Recht 与 Singer 给出了凸与非凸 SGD 的代表性稳定性分析[12]。

凸光滑更新不放大旧扰动，但访问替换观测仍会加入新扰动。若进一步具有强凸曲率且满足下一定理的步长条件，同一观测的更新还会缩小已有距离，让过去影响逐步衰减。这样可以得到不随训练轮数增长的界。我们在受控可行区域上陈述条件，分别要求曲率和梯度界，避免把全局强凸与全局有界梯度混用。

[12] M. Hardt, B. Recht, Y. Singer, *Train Faster, Generalize Better: Stability of Stochastic Gradient Descent* In Proceedings of the 33rd International Conference on Machine Learning, 2016, pp. 1225–1234

**定理 7.37　强凸投影 SGD 的稳定性**　设 $(Z, \mathcal{Z})$ 为可测观测空间，$\mathcal{W} \subseteq \mathbb{R}^d$ 是非空闭凸集，并令 $\mathcal{O} \subseteq \mathbb{R}^d$ 为包含 $\mathcal{W}$ 的开集。设 $\ell : \mathcal{O} \times Z \to \mathbb{R}$ 可测，且每个 $\ell(\cdot, z)$ 在 $\mathcal{O}$ 上二阶连续可微。对任意 $\boldsymbol{w} \in \mathcal{W}, z \in Z$，假定

$$\mu \boldsymbol{I} \preceq \nabla^2 \ell(\boldsymbol{w}, z) \preceq M \boldsymbol{I}, \qquad \|\nabla \ell(\boldsymbol{w}, z)\|_2 \leq L,$$

其中 $0 < \mu \leq M$。固定 $n, T \geq 1$、初值 $\boldsymbol{w}^{(0)} \in \mathcal{W}$ 及步长 $0 < \eta \leq 1/M$。任取 $Z$ 上的概率分布 $\mathcal{P}$ 并令 $S = (z_1, \ldots, z_n) \sim \mathcal{P}^n$。算法内部随机数

$U=(i_0,\dots,i_{T-1})$ 独立于 $S$，并由独立且均匀分布于 $\{1,\dots,n\}$ 的索引组成；算法更新

$$\boldsymbol{w}^{(t+1)}=\Pi_{\mathcal{W}}\big(\boldsymbol{w}^{(t)}-\eta\nabla\ell(\boldsymbol{w}^{(t)},z_{i_t})\big),\qquad t=0,\dots,T-1.$$

令 $A_{n,T}(S,U)=\boldsymbol{w}^{(T)}$。比较相邻样本时，两次运行共享初值和 $U$。则任意只相差一个观测的 $S,S'\in Z^n$ 及任意 $z\in Z$ 都满足

$$\left|\mathbb{E}_U\ell(A_{n,T}(S,U),z)-\mathbb{E}_U\ell(A_{n,T}(S',U),z)\right|\le\beta_{n,T},$$

其中

$$\beta_{n,T}\le\frac{2L^2}{\mu n}\big(1-(1-\mu\eta)^T\big)\le\frac{2L^2}{\mu n}.$$

**证明** 沿两参数之间的线段对 Hessian 积分，梯度更新的差等于 $(\boldsymbol{I}-\eta\boldsymbol{H})(\boldsymbol{u}-\boldsymbol{v})$，其中 $\boldsymbol{H}$ 的特征值位于 $[\mu,M]$。所以同一观测的更新将距离至多乘以 $1-\mu\eta$。投影不扩大距离。抽中替换位置时，再增加至多 $2L\eta$ 的扰动，故

$$D_{t+1}\le(1-\mu\eta)D_t+\frac{2L\eta}{n},\qquad D_0=0.$$

求和该几何级数，再乘损失的 Lipschitz 常数 $L$，即得结论。 ■

收缩用到的是每个单样本损失的曲率下界；只有平均经验风险强凸，还不能推出每一步收缩。二次正则项可以补充曲率，但也改变梯度界、光滑常数和比较目标。上述条件允许稳定性在长时间训练中保持受控，经验优化误差仍须另外估计。

要决定训练时长，我们接着把经验优化误差加入分析。下面使用投影 SGD，在每步将参数限制到指定球内，并输出迭代点平均。投影维持可行性，平均则通过凸性把各步损失转给最终输出。这一算法与直接输出最后一步不同。

**定理 7.38　平均投影 SGD 的期望风险保证** 设 $(Z,\mathcal{Z})$ 为可测观测空间，$\mathcal{W}=\{\boldsymbol{w}\in\mathbb{R}^d:\|\boldsymbol{w}\|_2\le B\}$，其中 $B\ge0$。令 $\mathcal{O}\subseteq\mathbb{R}^d$ 为包含 $\mathcal{W}$ 的开凸集，并设 $\ell:\mathcal{O}\times Z\to\mathbb{R}$ 可测。对每个 $z\in Z$，$\ell(\cdot,z)$ 在 $\mathcal{O}$ 上可微且凸；它在 $\mathcal{W}$ 上为 $L$-Lipschitz 且 $M$-光滑，其中 $M>0$，即

$$|\ell(\boldsymbol{u},z)-\ell(\boldsymbol{v},z)|\le L\|\boldsymbol{u}-\boldsymbol{v}\|_2,$$
$$\|\nabla\ell(\boldsymbol{u},z)-\nabla\ell(\boldsymbol{v},z)\|_2\le M\|\boldsymbol{u}-\boldsymbol{v}\|_2,\qquad \boldsymbol{u},\boldsymbol{v}\in\mathcal{W}.$$

固定 $Z$ 上的概率分布 $\mathcal{P}$，令 $S=(z_1,\dots,z_n)\sim\mathcal{P}^n$，并假定 $\ell(\mathbf{0},z)\in L^1(\mathcal{P})$。令算法内部随机数 $U=(i_0,\dots,i_{T-1})$ 独立于 $S$，其中各 $i_t$ 独立且均匀分布于 $\{1,\dots,n\}$。取 $n,T\ge 1$、初值 $\boldsymbol{w}^{(0)}=\mathbf{0}$ 和固定步长 $0<\eta\le 2/M$，并更新

$$\boldsymbol{w}^{(t+1)}=\Pi_{\mathcal{W}}\big(\boldsymbol{w}^{(t)}-\eta\nabla\ell(\boldsymbol{w}^{(t)},z_{i_t})\big),\qquad \bar{\boldsymbol{w}}=\frac{1}{T}\sum_{t=0}^{T-1}\boldsymbol{w}^{(t)}.$$

其中 $\Pi_{\mathcal{W}}$ 为欧氏投影。定义

$$R_{\mathcal{P}}(\boldsymbol{w})=\mathbb{E}_{z\sim\mathcal{P}}\ell(\boldsymbol{w},z),\qquad \hat{R}_S(\boldsymbol{w})=\frac{1}{n}\sum_{i=1}^{n}\ell(\boldsymbol{w},z_i)$$

分别为期望风险与经验风险。则

$$\mathbb{E}_{S,U}R_{\mathcal{P}}(\bar{\boldsymbol{w}})-\inf_{\boldsymbol{w}\in\mathcal{W}}R_{\mathcal{P}}(\boldsymbol{w})\le\frac{2L^2\eta T}{n}+\frac{B^2}{2\eta T}+\frac{\eta L^2}{2}.$$

若 $B,L>0$，取 $T=n$ 和 $\eta=B/(L\sqrt{n})\le 2/M$，右侧不超过 $3LB/\sqrt{n}$。

**证明**　若 $B=0$，可行集只有 $\mathbf{0}$，输出与比较风险相同，结论立即成立。以下设 $B>0$。投影不扩大距离，因此定理 7.36的轨迹比较仍成立。平均迭代点间的距离不超过各步距离的平均值，再用 Lipschitz 条件，得到平均输出的稳定性上界 $2L^2\eta T/n$。

固定 $S$ 及比较参数 $\boldsymbol{w}\in\mathcal{W}$，我们用迭代距离估计经验优化误差。记当前随机梯度为 $\boldsymbol{g}_t$，展开更新后的距离平方，并利用投影不会增加到可行点的距离，得到

$$2\eta\langle\boldsymbol{g}_t,\boldsymbol{w}^{(t)}-\boldsymbol{w}\rangle\le\|\boldsymbol{w}^{(t)}-\boldsymbol{w}\|_2^2-\|\boldsymbol{w}^{(t+1)}-\boldsymbol{w}\|_2^2+\eta^2L^2.$$

给定此前轨迹，梯度条件均值满足 $\mathbb{E}[\boldsymbol{g}_t]=\nabla\hat{R}_S(\boldsymbol{w}^{(t)})$；由凸性，内积的条件期望至少为 $\hat{R}_S(\boldsymbol{w}^{(t)})-\hat{R}_S(\boldsymbol{w})$。将各步相加，距离平方相消，初始距离至多 $B$，故

$$\frac{1}{T}\sum_{t=0}^{T-1}\mathbb{E}_U\hat{R}_S(\boldsymbol{w}^{(t)})-\hat{R}_S(\boldsymbol{w})\le\frac{B^2}{2\eta T}+\frac{\eta L^2}{2}.$$

平均参数的经验风险由凸性控制在各步风险平均之下。加上稳定性代价，再对固定比较参数取下确界，便得到所列风险保证。 ■

右侧三项分别计算样本扰动的泛化代价、有限迭代留下的经验误差，以及固定步长下的随机梯度误差。所给 $T,\eta$ 使它们都为 $1/\sqrt{n}$ 量级，因而支

持分布无关学习。最后一步输出与平均输出、固定训练集与每步新抽样，都改变了算法或抽样过程，须各用对应证明。

## 7.5 非凸学习问题

### 7.5.1 非凸性带来的变化

取消损失关于参数的凸性后，期望风险目标仍相同，但优化性质会改变。取 $h_w(x) = w^2 x$，在 $(x, y) = (1, 1)$ 上平方损失为 $(w^2 - 1)^2$；$w = \pm 1$ 为最小点，$w = 0$ 也有零梯度，损失却为 1。小梯度因此不足以说明经验风险接近最优。这个多项式只展示非凸形状，在整个实数轴上并不满足后面要求的全局 Lipschitz 性。

凸 SGD 还用到了同一更新不扩大参数距离。若只保留 $M$-光滑性，令 $G_{z,\eta}(\boldsymbol{w}) = \boldsymbol{w} - \eta \nabla \ell(\boldsymbol{w}, z)$，三角不等式只能给出

$$\|G_{z,\eta}(\boldsymbol{u}) - G_{z,\eta}(\boldsymbol{v})\|_2 \le (1 + M\eta)\|\boldsymbol{u} - \boldsymbol{v}\|_2.$$

这个因子允许早先的样本扰动被后续步骤放大。图 7.4固定初值、步长和参数平面，只改变二次目标的曲率：负曲率扩大距离，平坦方向保留距离，正曲率缩小距离。

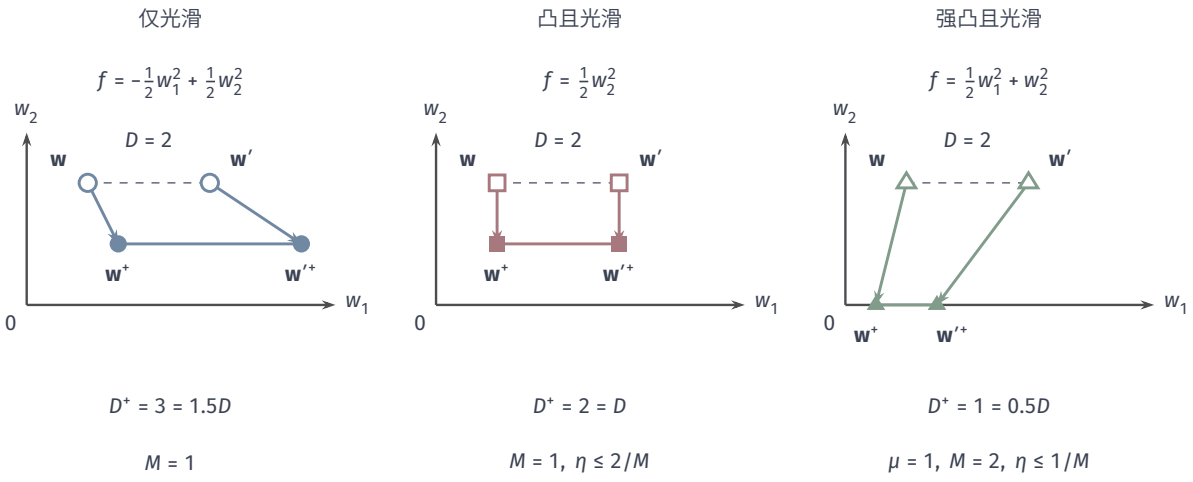


图 7.4　同一梯度更新如何影响参数距离。三个参数平面使用相同尺度，初值均为 $\boldsymbol{w} = (1, 2)^\top$、$\boldsymbol{w}' = (3, 2)^\top$，步长均为 $\eta = 1/2$。空心标记表示初值，实心标记表示 $\boldsymbol{w}^+ = \boldsymbol{w} - \eta \nabla f(\boldsymbol{w})$ 及 $\boldsymbol{w}'^+$；箭头表示各自的梯度步，虚线和实线连接更新前后的两点。图中二次函数的梯度步给出精确距离 $D^+ = 3, 2, 1$，并非一般情形的距离等式。凸且 $M$-光滑时，$\eta \le 2/M$ 保证不扩张；满足本章强凸光滑条件时，$\eta \le 1/M$ 保证至多以 $1 - \mu\eta$ 收缩。仅有光滑性不能排除扩张。

替换样本恒等式没有使用凸性，因此只要能控制轨迹距离，仍可得到期望泛化差。取消凸性后，需要补证的是轨迹为何接近，以及经验风险为何接近最优。下面分别处理这两个缺口。

### 7.5.2 非凸学习问题的正则化

我们先看能否用正则项消除负曲率。在欧氏凸决策集 $\mathcal{W}$ 上，$\kappa$-弱凸性要求加入 $\kappa\|\boldsymbol{w}\|_2^2/2$ 后目标变为凸，其中 $\kappa \geq 0$（可参考第一卷“最优化”章的欧氏弱凸性定义）。例如，$-\kappa w^2/2$ 恰需这一强度才变平，较小二次项仍保留负曲率。在开凸域上二阶可微时，这等价于 Hessian 特征值不小于 $-\kappa$；受限可行集上的弱凸性只约束该集合内的线段。正则强度必须与实际负曲率下界一起选择。

**定理 7.39　弱凸损失的正则化稳定性**　设 $(Z, \mathcal{Z})$ 为可测观测空间，$\mathcal{W} = \{\boldsymbol{w} \in \mathbb{R}^d : \|\boldsymbol{w}\|_2 \leq B\}$，其中 $B \geq 0$，并设 $\ell : \mathcal{W} \times Z \to \mathbb{R}$ 可测。固定 $\kappa \geq 0$ 和 $L \geq 0$；对每个 $z \in Z$，函数 $\boldsymbol{w} \mapsto \ell(\boldsymbol{w}, z) + \kappa\|\boldsymbol{w}\|_2^2/2$ 在 $\mathcal{W}$ 上凸，且

$$|\ell(\boldsymbol{u}, z) - \ell(\boldsymbol{v}, z)| \leq L\|\boldsymbol{u} - \boldsymbol{v}\|_2 \quad \text{对任意} \boldsymbol{u}, \boldsymbol{v} \in \mathcal{W}.$$

固定 $n \geq 1$ 并取 $\lambda > \kappa$。对 $S = (z_1, \dots, z_n) \in Z^n$，假设以下正则化目标的最小解存在，并定义可测算法

$$A_\lambda(S) = \operatorname*{arg\,min}_{\boldsymbol{w} \in \mathcal{W}} \left\{ \frac{1}{n} \sum_{i=1}^{n} \ell(\boldsymbol{w}, z_i) + \frac{\lambda}{2}\|\boldsymbol{w}\|_2^2 \right\}.$$

则对任意只相差一个观测的 $S, S' \in Z^n$ 及任意 $z \in Z$ 都有

$$|\ell(A_\lambda(S), z) - \ell(A_\lambda(S'), z)| \leq \beta_n, \qquad \beta_n \leq \frac{2L^2}{(\lambda - \kappa)n}.$$

进一步固定 $Z$ 上的概率分布 $\mathcal{P}$，令 $S \sim \mathcal{P}^n$，并令 $z \sim \mathcal{P}$ 独立于 $S$。若独立测试损失、训练损失以及每个固定 $\boldsymbol{w} \in \mathcal{W}$ 的 $\ell(\boldsymbol{w}, z)$ 均可积，则对任意固定 $\boldsymbol{w} \in \mathcal{W}$，定义

$$R_{\mathcal{P}}(\boldsymbol{v}) = \mathbb{E}_{z \sim \mathcal{P}} \ell(\boldsymbol{v}, z), \qquad \hat{R}_S(\boldsymbol{v}) = \frac{1}{n} \sum_{i=1}^{n} \ell(\boldsymbol{v}, z_i),$$

并且

$$\mathbb{E}_S R_{\mathcal{P}}(A_\lambda(S)) - R_{\mathcal{P}}(\boldsymbol{w}) \leq \frac{2L^2}{(\lambda - \kappa)n} + \frac{\lambda}{2}\|\boldsymbol{w}\|_2^2.$$

**证明**　正则化目标可以写成一个凸函数与 $(\lambda - \kappa)\|\boldsymbol{w}\|_2^2/2$ 之和，因而为 $(\lambda - \kappa)$-强凸。对相邻样本的两个最优解，重复定理 7.34的相加抵消论证，即得稳定性界。由正则化目标的最优性，经验风险相对于固定比较参数的差不超过 $\lambda\|\boldsymbol{w}\|_2^2/2$。再加上期望泛化差就得到第二式。 ■

$\kappa = 0$ 时，上界回到凸正则化的形式。$\kappa > 0$ 固定时，为保证强凸必须取 $\lambda > \kappa$，正则化系数便不能趋于零，整个比较空间上的正则化代价也不会自动消失。因此，这条定理给出稳定性与风险比较，却尚未证明原问题 PAC 可学习。算法若只找到局部极小值，全局最优性所用的比较同样需要另证。

### 7.5.3 非凸学习问题的随机梯度下降

也可以保留非凸目标，直接追踪相邻样本上的两条 SGD 轨迹。此时既要计算访问替换观测引入的扰动，也要计算后续共同更新对旧扰动的放大。学习率和迭代次数通过这两种作用进入期望泛化差上界。

**定理 7.40　非凸 SGD 的扰动传播**　设 $(Z, \mathcal{Z})$ 为可测观测空间，$\ell : \mathbb{R}^d \times Z \to \mathbb{R}$ 可测。对每个 $z \in Z$，$\ell(\cdot, z)$ 可微、$L$-Lipschitz 且 $M$-光滑，其中 $M > 0$，即

$$
\begin{aligned}
|\ell(\boldsymbol{u}, z) - \ell(\boldsymbol{v}, z)| &\le L \|\boldsymbol{u} - \boldsymbol{v}\|_2, \\
\|\nabla \ell(\boldsymbol{u}, z) - \nabla \ell(\boldsymbol{v}, z)\|_2 &\le M \|\boldsymbol{u} - \boldsymbol{v}\|_2, \qquad \boldsymbol{u}, \boldsymbol{v} \in \mathbb{R}^d.
\end{aligned}
$$

固定 $n, T \ge 1$、确定初值 $\boldsymbol{w}^{(0)} \in \mathbb{R}^d$ 及步长 $\eta_t \ge 0$。给定 $S = (z_1, \dots, z_n) \in Z^n$，令算法内部随机数 $U = (i_0, \dots, i_{T-1})$ 由独立且均匀分布于 $\{1, \dots, n\}$ 的索引组成；当 $S$ 随机时，$U$ 独立于 $S$。算法更新

$$
\boldsymbol{w}^{(t+1)} = \boldsymbol{w}^{(t)} - \eta_t \nabla \ell(\boldsymbol{w}^{(t)}, z_{i_t}), \qquad t = 0, \dots, T-1.
$$

令 $A_{n,T}(S, U) = \boldsymbol{w}^{(T)}$。比较相邻样本时，两次运行共享初值和 $U$。则任意只相差一个观测的 $S, S' \in Z^n$ 及任意 $z \in Z$ 都满足

$$
\left| \mathbb{E}_U \ell(A_{n,T}(S, U), z) - \mathbb{E}_U \ell(A_{n,T}(S', U), z) \right| \le \beta_{n,T},
$$

其中

$$
\beta_{n,T} \le \frac{2L^2}{n} \sum_{t=0}^{T-1} \eta_t \prod_{j=t+1}^{T-1} (1 + M\eta_j).
$$

其中空乘积取 1。若 $\mathcal{P}$ 为 $Z$ 上的概率分布，$S \sim \mathcal{P}^n$，$U$ 独立于 $S$，且独立测试损失与训练损失均可积，则

$$
R_{\mathcal{P}}(\boldsymbol{w}) = \mathbb{E}_{z \sim \mathcal{P}} \ell(\boldsymbol{w}, z), \qquad \hat{R}_S(\boldsymbol{w}) = \frac{1}{n} \sum_{i=1}^{n} \ell(\boldsymbol{w}, z_i),
$$

并且

$$\left|\mathbb{E}_{S,U}[R_{\mathcal{P}}(A_{n,T}(S,U)) - \hat{R}_S(A_{n,T}(S,U))]\right| \le \frac{2L^2}{n}\sum_{t=0}^{T-1}\eta_t \prod_{j=t+1}^{T-1}(1+M\eta_j).$$

**证明**　在相邻样本上使用相同随机索引，记两次迭代参数的平均距离为 $D_t$。未抽中替换位置时，光滑性给出放大因子 $1+M\eta_t$。抽中时，在同一观测的更新之外，再加入两个观测的梯度差；梯度范数均不超过 $L$，所以新增距离至多 $2L\eta_t$。由抽中概率 $1/n$，

$$D_{t+1} \le (1+M\eta_t)D_t + \frac{2L\eta_t}{n}, \qquad D_0 = 0.$$

逐步展开递推式，每一步产生的扰动都乘以后续更新的放大因子。最后用 Lipschitz 性将 $D_T$ 乘以 $L$，即得损失差上界。 ■

步长固定为 $\eta > 0$ 时，展开几何级数得到

$$\beta_{n,T} \le \frac{2L^2}{Mn}\big((1+M\eta)^T - 1\big).$$

这一最坏情形估计允许指数放大，但没有断言每个非凸算法的实际泛化差都指数增长。它指出仅靠光滑性无法为任意长训练提供小上界；减小步长、限制轮数或证明轨迹所在区域具有更好曲率，都可以改变扰动估计。

还可以利用首次访问的时间：在抽中替换观测以前，两条轨迹完全相同。如果首次访问时步长已经下降，后面的放大就弱于从初始时刻估计。下面给出 Hardt、Recht 与 Singer 这一思路的常数较宽松版本[13]。

**定理 7.41　递减步长的非凸 SGD 泛化界**　设 $(Z,\mathcal{Z})$ 为可测观测空间，$\ell : \mathbb{R}^d \times Z \to [0,1]$ 可测。对每个 $z \in Z$，$\ell(\cdot,z)$ 可微、$L$-Lipschitz 且 $M$-光滑，其中 $M > 0$，即

$$|\ell(\boldsymbol{u},z) - \ell(\boldsymbol{v},z)| \le L\|\boldsymbol{u}-\boldsymbol{v}\|_2,$$
$$\|\nabla\ell(\boldsymbol{u},z) - \nabla\ell(\boldsymbol{v},z)\|_2 \le M\|\boldsymbol{u}-\boldsymbol{v}\|_2, \qquad \boldsymbol{u},\boldsymbol{v} \in \mathbb{R}^d.$$

固定 $n, T \ge 1$、确定初值 $\boldsymbol{w}^{(0)} \in \mathbb{R}^d$ 及 $c > 0$。任取 $Z$ 上的概率分布 $\mathcal{P}$ 并令 $S = (z_1,\dots,z_n) \sim \mathcal{P}^n$。算法内部随机数 $U = (i_0,\dots,i_{T-1})$ 独立于 $S$，并由独立且均匀分布于 $\{1,\dots,n\}$ 的索引组成；算法以 $0 \le \eta_t \le c/(t+1)$ 更新

$$\boldsymbol{w}^{(t+1)} = \boldsymbol{w}^{(t)} - \eta_t \nabla\ell(\boldsymbol{w}^{(t)}, z_{i_t}), \qquad t = 0,\dots,T-1.$$

令 $A_{n,T}(S,U)=\boldsymbol{w}^{(T)}$，并在相邻样本上共享初值与 $U$。定义 $\beta_{n,T}$ 为满足

$$\left|\mathbb{E}_U \ell(A_{n,T}(S,U),z)-\mathbb{E}_U \ell(A_{n,T}(S',U),z)\right|\le \beta_{n,T}$$

对任意只相差一个观测的 $S,S'\in Z^n$ 及任意 $z\in Z$ 成立的稳定性上界。记 $a=Mc$。对任意整数 $1\le t_0\le T$，有

$$\beta_{n,T}\le \frac{t_0}{n}+\frac{2L^2}{Mn}\left(\frac{T}{t_0}\right)^{a}.$$

特别地，取 $t_0=\lceil T^{a/(a+1)}\rceil$，可得

$$\beta_{n,T}\le \frac{1+(1+2L^2/M)T^{a/(a+1)}}{n}.$$

**证明**　前 $t_0$ 次抽样中至少一次选中替换位置的概率不超过 $t_0/n$。在这一事件上用损失差至多 $1$ 估计。在其补事件上，两条轨迹在时刻 $t_0$ 完全相同，后续索引仍独立均匀，因而可从 $D_{t_0}=0$ 开始使用前一定理的递推式。利用 $1+u\le e^{u}$ 及调和和的积分上界，有

$$\prod_{j=t+1}^{T-1}\left(1+\frac{a}{j+1}\right)\le\left(\frac{T}{t+1}\right)^{a}.$$

所以后续的条件期望损失差至多为

$$\frac{2cL^2T^{a}}{n}\sum_{t=t_0}^{T-1}(t+1)^{-a-1}\le\frac{2cL^2T^{a}}{an}\,t_0^{-a}.$$

这里使用 $\sum_{t=t_0}^{T-1}(t+1)^{-a-1}\le\int_{t_0}^{T}x^{-a-1}\,dx\le t_0^{-a}/a$。合并两种事件，并代入 $a=Mc$ 得到第一式。再代入所给 $t_0$，利用 $T^{a/(a+1)}\le t_0\le T^{a/(a+1)}+1$ 即得第二式。 ∎

固定 $L,M,c$，令 $T=n$，上界为 $n^{-1/(a+1)}$ 量级。若 $T$ 按 $n^{p}$ 增长，$p<(a+1)/a$ 仍足以使稳定性代价下降，因此允许一定次数的重复访问。不过，得到的仍是期望泛化差。要接近最优期望风险，还须证明 $\rho_{n,T}\to 0$；步长和轮数条件本身不会保证算法找到经验好解。

我们现在为经验优化加入结构。Polyak–Łojasiewicz 条件，简称 PL 条件，用梯度范数控制目标高于最优值的差：只要目标尚未最优，梯度就必须具有相应大小。它排除高损失的零梯度点，而不要求所有方向具有非负曲率，因而可以适用于某些非凸问题（可参考第一卷“最优化”章的 PL 条件定义）。本章将它用于经验目标 $F$ 与指定参数区域，以有限下确界 $F_{*}=\inf_{\boldsymbol{w}\in\mathcal{W}}F(\boldsymbol{w})$ 为基准；同一个 $\mu>0$ 须使指定区域内每点的梯度范数

平方至少为 $2\mu(F(\boldsymbol{w})-F_*)$。下面的学习定理进一步说明哪些迭代点及样本需要满足这一要求。

$F(w)=w^2/2$ 在 $\mu=1$ 时满足等式；前面的 $(w^2-1)^2$ 却在 $w=0$ 处违反条件，因为梯度为零而最优值差为正。非凸函数也可能满足 PL，例如 $w^2+3\sin^2 w$ 具有正参数的全局 PL 条件，但部分位置的二阶导数为负[14]。PL 限制的是梯度与最优值差，而不是逐方向曲率。

SGD 使用单样本梯度，即使经验目标满足 PL，当前梯度仍会围绕经验梯度波动。下面保留这一方差代价，与初始优化误差及稳定性一起计算。

[14] H. Karimi, J. Nutini, M. Schmidt, *Linear Convergence of Gradient and Proximal-Gradient Methods Under the Polyak–Lojasiewicz Condition* In arXiv preprint arXiv:1608.04636, 2016

**定理 7.42　PL 条件下非凸 SGD 的学习保证**　设 $(Z,\mathcal{Z})$ 为可测观测空间，$\mathcal{W}\subseteq\mathbb{R}^d$ 为非空凸 Borel 区域，并令 $\mathcal{O}\subseteq\mathbb{R}^d$ 为包含 $\mathcal{W}$ 的开集。设 $\ell:\mathcal{O}\times Z\to\mathbb{R}$ 可测，且各单样本损失在 $\mathcal{O}$ 上关于参数可微；存在 $M>0$ 和 $L\geq 0$，使任意 $\boldsymbol{u},\boldsymbol{v}\in\mathcal{W}, z\in Z$ 都满足

$$\|\nabla\ell(\boldsymbol{u},z)-\nabla\ell(\boldsymbol{v},z)\|_2\leq M\|\boldsymbol{u}-\boldsymbol{v}\|_2,\qquad \|\nabla\ell(\boldsymbol{u},z)\|_2\leq L.$$

对每个允许分布 $\mathcal{P}$，令 $S=(z_1,\dots,z_n)\sim\mathcal{P}^n$，并定义

$$\hat{R}_S(\boldsymbol{w})=\frac{1}{n}\sum_{i=1}^{n}\ell(\boldsymbol{w},z_i),\qquad R_{\mathcal{P}}(\boldsymbol{w})=\mathbb{E}_{z\sim\mathcal{P}}\ell(\boldsymbol{w},z).$$

固定初值 $\boldsymbol{w}^{(0)}\in\mathcal{W}$、步长 $0<\eta\leq 1/M$ 及 $T\geq 1$。令算法内部随机数 $U=(i_0,\dots,i_{T-1})$ 独立于 $S$，其中各 $i_t$ 独立且均匀分布于 $\{1,\dots,n\}$，并更新

$$\boldsymbol{w}^{(t+1)}=\boldsymbol{w}^{(t)}-\eta\nabla\ell(\boldsymbol{w}^{(t)},z_{i_t}),\qquad t=0,\dots,T-1.$$

假定对所有样本和索引序列，全部迭代点均留在 $\mathcal{W}$ 内。存在 $0<\mu\leq M$ 及 $D\geq 0$，使每个样本及其每个迭代点都满足

$$\frac{1}{2}\|\nabla\hat{R}_S(\boldsymbol{w}^{(t)})\|_2^2\geq\mu\Big(\hat{R}_S(\boldsymbol{w}^{(t)})-\inf_{\boldsymbol{w}\in\mathcal{W}}\hat{R}_S(\boldsymbol{w})\Big),$$
$$\hat{R}_S(\boldsymbol{w}^{(0)})-\inf_{\boldsymbol{w}\in\mathcal{W}}\hat{R}_S(\boldsymbol{w})\leq D.$$

进一步设存在 $\nu\geq 0$，使对所有 $S\in Z^n$ 和 $\boldsymbol{w}\in\mathcal{W}$ 都有

$$\frac{1}{n}\sum_{i=1}^{n}\|\nabla\ell(\boldsymbol{w},z_i)-\nabla\hat{R}_S(\boldsymbol{w})\|_2^2\leq\nu^2.$$

假定独立测试损失 $\ell(\boldsymbol{w}^{(T)}, z)$、训练损失 $\ell(\boldsymbol{w}^{(T)}, z_i)$ 及每个固定 $\boldsymbol{w} \in \mathcal{W}$ 的 $\ell(\boldsymbol{w}, z)$ 均可积，并且经验风险与期望风险的下确界为有限实数且可测。则

$$\begin{aligned}&\mathbb{E}_{S,U} R_{\mathcal{P}}(\boldsymbol{w}^{(T)}) - \inf_{\boldsymbol{w}\in\mathcal{W}} R_{\mathcal{P}}(\boldsymbol{w}) \\ &\quad \le \frac{2L^2}{Mn}\big((1+M\eta)^T - 1\big) + D(1-\mu\eta)^T + \frac{M\eta\nu^2}{2\mu}.\end{aligned}$$

**证明** 定理 7.40的轨迹比较给出第一项均匀稳定性上界。为分析经验优化误差，固定样本及此前的迭代结果，记 $\boldsymbol{g}_t = \nabla \ell(\boldsymbol{w}^{(t)}, z_{i_t})$。条件均值满足 $\mathbb{E}\boldsymbol{g}_t = \nabla \hat{R}_S(\boldsymbol{w}^{(t)})$，条件二阶矩满足

$$\mathbb{E}\|\boldsymbol{g}_t\|_2^2 \le \|\nabla \hat{R}_S(\boldsymbol{w}^{(t)})\|_2^2 + \nu^2.$$

将更新代入光滑性不等式，并对当前索引取期望，得到

$$\mathbb{E}\hat{R}_S(\boldsymbol{w}^{(t+1)}) \le \hat{R}_S(\boldsymbol{w}^{(t)}) - \frac{\eta}{2}\|\nabla \hat{R}_S(\boldsymbol{w}^{(t)})\|_2^2 + \frac{M\eta^2\nu^2}{2}.$$

这里使用 $\eta \le 1/M$。由 PL 条件，平均经验优化误差 $e_t$ 满足

$$e_{t+1} \le (1-\mu\eta)e_t + \frac{M\eta^2\nu^2}{2}, \qquad e_0 \le D.$$

求和几何级数，得到 $e_T \le D(1-\mu\eta)^T + M\eta\nu^2/(2\mu)$。再加上稳定性控制的期望泛化差，即得结论。 ■

三项分别衡量样本替换的影响、未消除的初始经验误差，以及随机梯度波动。固定非零步长时，方差项不会因延长训练而消失，稳定性代价还可能上升。改用全梯度后，方差为零，可得到相应的全梯度学习保证。

若 $L, M, \mu, D, \nu$ 对分布和样本量统一，可以同时让步长下降、总步长缓慢增加。取 $\eta_n = n^{-r}$、$r > 0$，令 $T_n = \lfloor c_0 \log n/\eta_n \rfloor$，其中 $0 < c_0 < 1/M$，充分大 $n$ 满足步长要求。三项分别为 $O(n^{Mc_0-1})$、$O(n^{-\mu c_0})$ 和 $O(n^{-r})$，均趋于零，从而得到分布无关 PAC 保证。这说明非凸并不自动阻止学习，但统一 PL、迭代区域和梯度条件都需要针对实际问题证明，不能由训练曲线下降代替。

## 7.6 本章小结

对一般损失，学习保证需要同时说明候选决策怎样受控，以及算法怎样从样本选择结果。一致收敛估计整个损失函数空间，稳定性估计算法实际输出的泛化差，二者都要加入经验优化要求。改变损失后，分类模式计数也

须改为带数值尺度的容量分析：伪维使用逐点阈值，胖打散维增加指定间隔。在有界性和可测性条件下，允许全部分布时，各正尺度的有限胖打散维刻画一致收敛；限制分布族后，它仍是充分条件，必要方向却未必保留。

一般学习基本定理进一步说明，是否可学习等价于是否存在适当稳定且渐近经验最优的算法。存在性允许重新构造算法；经验最优性排除了稳定却始终选择高风险决策的情形。它既不要求每个成功算法满足同一种稳定性，也没有把稳定性单独当作学习目标。

各类稳定性提供的保证依赖其比较方式。留一法连接 $n$ 与 $n-1$ 项算法，平均替换直接对应期望泛化差，均匀条件可在有界损失下进一步支持集中分析。参数距离要经 Lipschitz 性或非负光滑损失的自界关系转换，信息量则通过参照分布控制依赖代价。由平均风险进入分布无关 PAC 保证时，经验优化误差也必须下降，且两项速率统一适用于允许分布。

正则化、步长和停止时刻使这些条件落实到具体算法：曲率限制扰动，惩罚与早停又可能留下拟合代价。非凸问题需要额外检查光滑性、轨迹区域和优化条件，才能把两种误差一同降下去。下一章将这条分析应用于神经网络，考察参数大小、初始梯度、更新轨迹和参数分布分别如何约束期望风险。

**延伸阅读**　Shalev-Shwartz 等的论文将可学习性、稳定性与一致收敛放在一般损失框架内比较。可结合本章的基本定理，检查各渐近经验最优条件平均了哪些随机量，以及必要性为何允许构造新的算法[15]。

Bousquet 与 Elisseeff 讨论稳定性如何进入风险与集中保证；Hardt、Recht 与 Singer 进一步分析 SGD。对照阅读时，可以追踪同一观测更新是否收缩、替换观测如何引入扰动，以及这些递推在凸与非凸情形中怎样改变[16,17]。

Steinke 与 Zakynthinou 的条件互信息分析把学习、压缩和信息量联系起来。阅读时可回到本章的双样本构造，分别写出被保留的联合分布与被重新抽取的选择变量，从而看清它与普通互信息的参照过程为何不同[18]。

[15] S. Shalev-Shwartz, O. Shamir, N. Srebro, K. Sridharan, *Learnability, Stability and Uniform Convergence* In Journal of Machine Learning Research, 2010, vol. 11, no. 90, pp. 2635–2670

[16] O. Bousquet, A. Elisseeff, *Stability and Generalization* In Journal of Machine Learning Research, 2002, vol. 2, pp. 499–526

[17] M. Hardt, B. Recht, Y. Singer, *Train Faster, Generalize Better: Stability of Stochastic Gradient Descent* In Proceedings of the 33rd International Conference on Machine Learning, 2016, pp. 1225–1234

[18] T. Steinke, L. Zakynthinou, *Reasoning About Generalization via Conditional Mutual Information* In Proceedings of the Thirty Third Conference on Learning Theory, 2020, pp. 3437–3452

第 8 章

# 深度学习的可学习性

设一个邮件分类网络已经把训练邮件全部分对。我们再增加参数，新的训练结果仍可分对这些邮件，却可能在新邮件上达到更低错误率。仅用“参数越多越容易记忆”无法解释这种可能性，因为架构允许表示什么函数，与训练最后选择哪个函数，是两个问题。同一架构既能记住训练邮件，也可能表示能够推广到新邮件的分类关系。

前面的学习理论提供了不同分析对象：VC 维与一致收敛约束整个候选空间，稳定性比较样本变化对算法输出的影响，并须结合经验最优性。要用于网络，我们需具体追踪权重怎样约束函数、训练怎样选择解、样本替换怎样影响参数和损失。下面对能够直接处理的非线性网络列明架构和范数条件；对难以完整求解的选解问题，则用线性回归、线性分类及深层线性网络建立机制，再说明推广边界。

我们从四种对象进入这个共同问题。权重范数约束所选函数的复杂度，初始参数梯度在特定宽度与训练条件下给出近似固定特征，参数更新描述训练对解的偏好，参数分布则分别描述神经元群体和随机完整网络。这些对象都须经复杂度或稳定性推导接到风险，并保留近似能力与优化条件。模型规模、训练时间、任务或评价分布改变时，应按第 4.1节重新固定学习问题；本章在明确的设定中分析选解与泛化。

## 8.1 神经网络的学习问题

### 8.1.1 网络与学习目标

我们先固定待分析的预测函数。前馈网络在每层用权重矩阵组合输入，再逐坐标应用激活，末层作线性输出。ReLU 激活 $\phi(a) = \max\{0, a\}$ 保留正值、将负值置零，多层组合因而一般不再等价于一次线性变换。省略偏置，将包括线性输出层在内的变换层数记为 $L$，网络为

$$f_{\boldsymbol{W}}(\boldsymbol{x}) = \boldsymbol{W}_L \phi\big(\boldsymbol{W}_{L-1} \phi(\cdots \phi(\boldsymbol{W}_1 \boldsymbol{x}) \cdots)\big), \tag{8.1}$$

其中 $\boldsymbol{W}_\ell \in \mathbb{R}^{d_\ell \times d_{\ell-1}}$，$d_0$ 为输入维度，$d_1, \dots, d_{L-1}$ 为隐藏宽度，$d_L$ 为输出维度，最大宽度为 $w = \max_{0 \le \ell \le L} d_\ell$。全部参数组成 $\theta \in \mathbb{R}^p$ 时，也记为 $f_\theta$。$p$ 计数可调数值，$L$ 计数依次变换次数，两者都不是 VC 维。第三卷以 $L$ 计隐藏层数；这里换算时暂将其记为 $L_{\mathrm{h}}$，于是本章 $L = L_{\mathrm{h}} + 1$，外部结果也统一按总变换层数理解。

为了评价网络，取独立同分布样本 $S = (z_1, \dots, z_n) \sim \mathcal{P}^n$，$z_i = (\boldsymbol{x}_i, y_i)$。预测级损失记为 $\ell_{\mathrm{pred}}(\hat{y}, y)$，由参数产生的观测级损失则为 $\ell_\theta(z) = \ell_{\mathrm{pred}}(f_\theta(\boldsymbol{x}), y)$，这样便接到第 4.1节的一般记号。样本与总体分别平均这一损失：

$$\hat{R}_S(\theta) = \frac{1}{n} \sum_{i=1}^{n} \ell_\theta(z_i), \qquad R_{\mathcal{P}}(\theta) = \mathbb{E}_{z \sim \mathcal{P}} \ell_\theta(z).$$

算法利用经验风险选择参数，期望风险评价同分布新观测。分布明确时简写为 $R(\theta)$。讨论错误率采用零一损失，推导梯度更新时则另行列明平方或逻辑损失，以免混用目标。

给定样本上存在零经验风险参数，称模型能够**插值**（interpolation）这份样本。平方损失要求预测数值逐项等于标签，零一损失只要求类别正确；交叉熵通常随分数增大才趋近零，所以类别全部正确并不等于交叉熵为零。**过参数化**（overparameterization）描述参数相对于样本或拟合约束很充足的情形，常以 $p > n$ 粗略表示。是否实际插值仍取决于架构、数据和损失。

### 8.1.2 VC 维与样本量

固定架构后，可以把它能表示的分类器作为假设空间，沿前面的 VC 理论推导样本量。Baum 与 Haussler 在 1988 年研究了网络规模与泛化样本数的关系，包括阈值网络[1]。这一分析先控制候选空间的 VC 维，再给出分布无关统计保证，尚无需描述每一步训练更新。

容量还依赖计算结构，不能仅由参数量读取。对分段线性网络，Bartlett 等给出 ReLU 网络 $O(pL \log p)$ 的 VC 维上界，并在相应参数范围内构造达到 $\Omega(pL \log(p/L))$ 的架构[2]。下界证明的是某些架构能够达到这一容量，不能移作每个 $p$ 参数网络的下界。

有了架构容量上界，就能代入二分类学习基本定理。下面把这一步统计推导单独写出，保留算法存在性与实际优化之间的区别：存在近似 ERM 学习算法，不保证梯度下降能找到对应参数。

[1] E. B. Baum, D. Haussler, *What Size Net Gives Valid Generalization?* In Advances in Neural Information Processing Systems, 1988

[2] P. L. Bartlett, N. Harvey, C. Liaw, A. Mehrabian, *Nearly-tight VC-dimension and Pseudodimension Bounds for Piecewise Linear Neural Networks* In Journal of Machine Learning Research, 2019, vol. 20, no. 63, pp. 1–17

**定理 8.1 有限 VC 维网络的不可知 PAC 样本量保证** 设 $(X, \mathcal{X})$ 为可测输入空间，$Y = \{0,1\}$，$Z = X \times Y$ 取乘积 $\sigma$ 代数。固定网络架构所表示的非空二分类假设空间 $\mathcal{H} \subseteq Y^X$ 由可测函数组成，其 VC 维为有限数 $d \geq 1$。对 $Z$ 上的任意概率分布 $\mathcal{P}$，令 $S = ((x_1, y_1), \dots, (x_n, y_n)) \sim \mathcal{P}^n$，并定义零一损失下的

$$R_{\mathcal{P}}(h) = \mathbb{P}_{(x,y)\sim\mathcal{P}}\{h(x) \neq y\}, \qquad \hat{R}_S(h) = \frac{1}{n}\sum_{i=1}^{n} \mathbb{I}\{h(x_i) \neq y_i\}.$$

假设随机变量 $\sup_{h\in\mathcal{H}} |\hat{R}_S(h) - R_{\mathcal{P}}(h)|$ 可测。存在通用常数 $c > 0$，使得任意 $\varepsilon, \delta \in (0,1)$ 和任意 $\mathcal{P}$ 下，只要

$$n \geq c\frac{d\log(2/\varepsilon) + \log(2/\delta)}{\varepsilon^2},$$

每个满足 $\hat{R}_S(\hat{h}) = \inf_{h\in\mathcal{H}} \hat{R}_S(h)$ 的经验风险最小化算法输出 $\hat{h}$ 都以至少 $1-\delta$ 的概率满足

$$R_{\mathcal{P}}(\hat{h}) \leq \inf_{h\in\mathcal{H}} R_{\mathcal{P}}(h) + \varepsilon.$$

**证明** 由有限 VC 维的一致收敛结论，在所给样本量下，可以使事件 $\sup_{h\in\mathcal{H}} |\hat{R}_S(h) - R_{\mathcal{P}}(h)| \leq \varepsilon/2$ 以至少 $1-\delta$ 的概率成立。在该事件上，对任意 $h \in \mathcal{H}$ 有

$$R_{\mathcal{P}}(\hat{h}) \leq \hat{R}_S(\hat{h}) + \frac{\varepsilon}{2} \leq \hat{R}_S(h) + \frac{\varepsilon}{2} \leq R_{\mathcal{P}}(h) + \varepsilon.$$

对右侧的 $h$ 取下确界即可。证明使用了 ERM 的经验风险比较性质，没有给出实现 ERM 的计算方法。 ■

因此，固定有限架构可以在所列前提下获得统计学习保证。若手头样本数 $n$ 远小于容量给出的充分门槛，这条定理就无法保证指定精度。另有适用于任意 $n$ 的 VC 风险界，但它可能大于 1 而空泛，不能将它与前提尚未满足的样本量定理混同。实际训练若只实现近似 ERM，还须计入经验优化误差。

### 8.1.3 过参数化的挑战

随机标签实验揭示了容量与所选函数之间的差距。Zhang 等报告一些深度网络既能拟合真实标签，也能拟合随机打乱的标签[3]。两种结果共享强表达能力，却可能有不同期望风险；只根据架构无法判断算法选择哪一种。图 8.1分别画出架构允许的全部假设、拟合当前样本的插值集合，以及算法实际选出的一个点。风险分析最终需要评价这个点。

[3] C. Zhang, S. Bengio, M. Hardt, B. Recht, O. Vinyals, *Understanding Deep Learning (Still) Requires Rethinking Generalization* In Communications of the ACM, 2021, vol. 64, no. 3, pp. 107–115

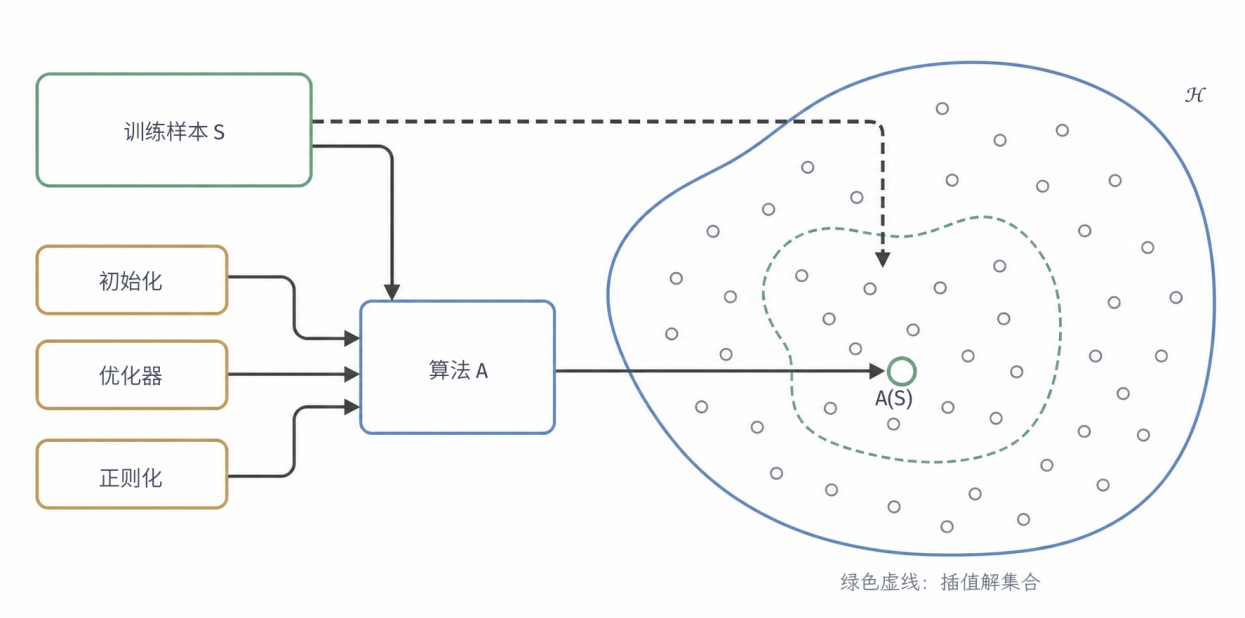


图 8.1 架构、样本和算法分别限定不同对象。外层是假设空间，内层是当前样本上经验风险为零的插值解集合；虚线表示样本施加的约束，实线表示算法的输入与输出。初始化、优化器和正则化参与选解。强调点仅示意算法选出一个插值解，不保证任意算法都实现插值；集合的形状和大小没有数值含义，插值也不保证期望风险小。

插值集合中可以有只记住训练邮件、对新邮件默认分类的函数，也可以有利用促销词和链接关系的函数。在零一损失下，两者都可使训练风险为零，后一种却可能在新邮件上继续有效。扩大参数空间可能同时方便表示这两种函数，因此插值解增多并没有确定风险变化的方向。

即使样本和架构固定，初始化、步长、优化器或正则化也可能使算法选出不同插值解。图中的算法箭头因而补充了集合大小无法说明的信息。我们要找的是所选解有哪些复杂度约束，以及训练为何偏向这些解；后面的范数、轨迹与分布分析分别回答这一问题。

某些模型在接近插值阈值时风险上升，继续增加参数后却下降，这种形态称为**双重下降**（double descent）[4]。图 8.2作定性示意。一种可能机制是：阈值附近拟合噪声需要敏感的解，越过阈值后更多插值选择允许算法得到范数较小或较稳定的解。这一解释依赖数据与选解方式，不提供增加参数总能降低风险的保证。

图 8.2中的两条曲线评价不同对象。经验风险到零附近，只说明拟合了当前样本；期望风险的峰值说明新观测损失在该设定中较高。要将峰值归因于敏感选解，仍须另行比较相邻样本或噪声响应。右侧风险下降则展示增加参数后可能选到更合适的插值函数。这些差别都无法仅从训练风险判断。

可解的欠定线性回归说明算法为何重要。它可能有无穷多个插值解，零初始化梯度下降却选择最小欧氏范数解，并非随机等概率选择。增加参数

[4] M. Belkin, D. Hsu, S. Ma, S. Mandal, *Reconciling Modern Machine-Learning Practice and the Classical Bias–Variance Trade-Off* In Proceedings of the National Academy of Sciences, 2019, vol. 116, no. 32, pp. 15849–15854

会改变这个解及其噪声响应，风险也可能随之改变。第 8.4节将证明选解机制，并进一步检查风险条件。

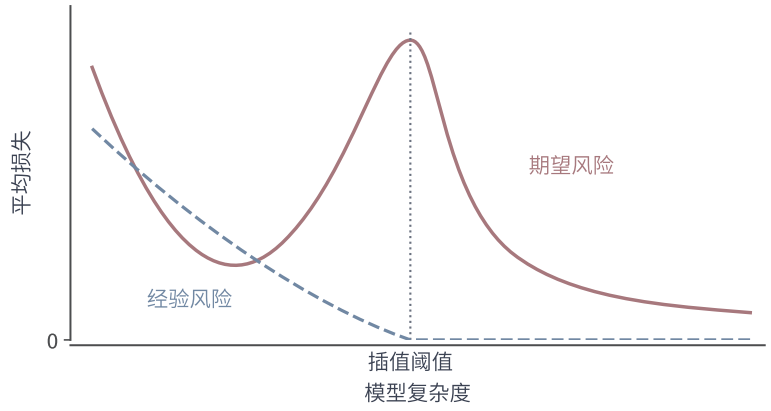


图 8.2　双重下降的定性示意。虚线表示经验风险，实线表示一种可能出现的期望风险变化。插值后的期望风险还取决于算法如何选解。图中曲线用于说明概念，不是实验数据，也不表示所有网络都出现第二次下降。

下面四条路线都在补充算法选择的信息。范数限制函数变化，初始梯度建立近似固定特征，更新动力学决定解的偏好，参数分布描述神经元演化或随机网络。它们的研究时间相互交叠，也共同借助复杂度和稳定性工具，不能当作彼此替代的顺次阶段。

### 8.1.4 从一般学习理论到神经网络

为了让各路线回答同一个问题，我们把低训练损失与低总体损失之间的分析写成风险分解。算法 $A$ 输出属于比较空间 $\mathcal{H}$ 时，分别记期望泛化差与经验优化误差为

$$\Delta_n = \mathbb{E}_S\big[R(A(S)) - \hat{R}_S(A(S))\big],$$
$$\rho_n = \mathbb{E}_S\left[\hat{R}_S(A(S)) - \inf_{h\in\mathcal{H}} \hat{R}_S(h)\right].$$

相关期望存在时，有

$$\mathbb{E}_S R(A(S)) - \inf_{h\in\mathcal{H}} R(h) \le \Delta_n + \rho_n. \tag{8.2}$$

因为固定 $h$ 满足 $\mathbb{E}_S \hat{R}_S(h) = R(h)$，而 $\mathbb{E}_S \inf_h \hat{R}_S(h) \le \inf_h R(h)$，分解后便得到此式。第一项比较经验与总体评价，第二项比较算法与经验最优值；共同受控才使输出接近 $\mathcal{H}$ 内最优风险。训练降低经验损失时，第一项仍可能增大。

一致收敛与稳定性分别控制这里的 $\Delta_n$。前者估计固定函数空间中所有假设的风险，后者比较不同训练样本产生的算法输出。因此，架构保持不变时，初始化、正则化和优化仍可能改变稳定性，而不会改变架构的 VC 维。

权重大小可以参与两条路线。预先限制范数，可估计受限函数空间复杂度；比较样本替换后的参数时，范数又能限制参数变化向损失变化的放大。但后一条还须证明两次参数确实接近，单有小范数不够。参数分布也须经分布距离或信息量接到风险，不能由分布形式本身判断泛化。

这些路径不能绕过不可学习性。零一二分类若允许任意输入—标签联合分布，无限 VC 维空间仍不可分布无关 PAC 学习，稳定性分析不会改变这点。不显含宽度的后续结论会保留范数、间隔或分布条件；它们评价这些条件下的风险，不是整个无限 VC 维空间的无约束保证。

比较各结果时，我们会固定其损失和概率对象。高概率风险界、样本平均风险界与经验风险下降速度分别回答不同问题，不能互相替代；每条路径也须保留它对训练算法的额外要求。

## 8.2 基于参数大小的可学习性

架构容量同时包括拟合随机标签和可推广关系的函数，因而按参数计数可能得到过大的样本门槛。若我们事先将候选函数限制在较小范数范围，就可以估计这个受限空间的复杂度。权重范数在此作为可计算的约束，补充参数数量没有描述的函数信息。

这里“参数大小”计量向量或矩阵的范数，区别于数值个数。较强的局部变化可能需要较大权重放大，限制各层共同放大能力便能约束这些变化。本节先固定范数范围，估计其中全部网络的经验风险与总体风险关系；训练如何得到这样的权重，留给后面的算法分析。

多层权重并不能简单相加：各层范数怎样组合、等价缩放怎样影响范数，以及分类间隔如何参与评价，都需要说明。不显含宽度的界也须保留这些条件，并不自动保证梯度下降找到满足条件的解。我们先建立范数与风险的联系，再追踪训练选择。

### 8.2.1 权重大小与分类间隔

从线性预测看，$|\langle \boldsymbol{w}, \boldsymbol{x}-\boldsymbol{x}' \rangle| \le \|\boldsymbol{w}\|_2 \|\boldsymbol{x}-\boldsymbol{x}'\|_2$，范数控制输入变化对分数的放大。即使参数数量相同，不同权重仍可产生不同敏感度。网络范数分析沿此思路考察参数共同形成的函数，而非只计参数。Bartlett 在 1996 年研究了适当条件下权重大小对泛化保证的作用[5]。

[5] P. L. Bartlett, *For Valid Generalization the Size of the Weights is More Important than the Size of the Network* In Advances in Neural Information Processing Systems, 1996

对于分类，还要知道分数与类别边界的距离。真实类别为第一类时，$(3,2,0)$ 与 $(2.01,2,0)$ 都分类正确，但领先第二名的幅度分别为 1 和 0.01。后者容许的分数扰动更小。我们将真实类别领先其余类别的幅度称为分类间隔。

**定义 8.2　分类间隔**　设 $f_{\boldsymbol{W}}:X\to\mathbb{R}^K$ 是分类分数函数。其在带标签输入 $(\boldsymbol{x},y)$ 处的分类间隔定义为

$$\operatorname{margin}_{\boldsymbol{W}}(\boldsymbol{x},y)=f_{\boldsymbol{W}}(\boldsymbol{x})_y-\max_{j\neq y} f_{\boldsymbol{W}}(\boldsymbol{x})_j. \tag{8.3}$$

对于取值为 $\{-1,+1\}$ 的二分类标签和标量分数 $f(\boldsymbol{x})$，定义间隔为 $yf(\boldsymbol{x})$。

间隔为正时，真实类别分数高于其余类别。若各分数最多变化 $\alpha$，领先幅度最多改变 $2\alpha$，所以间隔大于 $2\alpha$ 仍保留正确分类。范数要与间隔一起评价：统一放大分数同时放大二者，却不改变分类函数或错误率。

### 8.2.2 不显含宽度的期望风险界

先看两层 ReLU 网络。增加隐藏宽度增加了可选特征，但输出权重绝对值之和受限时，网络不能同时任意放大每个特征。下面允许任意隐藏单元数，用这个总量和隐藏权重范数约束函数空间。

**定理 8.3　两层网络的范数与期望风险**　设 $n,d\geq 1$，$X\subseteq\mathbb{R}^d$ 取 Borel $\sigma$ 代数，$Y=\{-1,+1\}$，$\mathcal{P}$ 为 $X\times Y$ 上的概率分布，且 $S=((\boldsymbol{x}_1,y_1),\dots,(\boldsymbol{x}_n,y_n))\sim\mathcal{P}^n$。假设 $\|\boldsymbol{x}\|_2\leq r$ 在 $\mathcal{P}$ 下几乎处处成立。在抽样前固定 $A,B,r,\gamma>0$ 及 $\delta\in(0,1)$，并令

$$\mathcal{F}_{A,B}=\left\{\boldsymbol{x}\mapsto\sum_{j=1}^{m}a_j\phi(\boldsymbol{w}_j^{\top}\boldsymbol{x}):m\in\mathbb{N},\ \sum_{j=1}^{m}|a_j|\leq A,\ \|\boldsymbol{w}_j\|_2\leq B\right\},$$

其中 $\phi(a)=\max\{0,a\}$。则任意满足 $\|\boldsymbol{x}_i\|_2\leq r$ 的输入样本上的经验 Rademacher 复杂度满足

$$\widehat{\mathfrak{R}}_S(\mathcal{F}_{A,B})\leq\frac{2ABr}{\sqrt{n}}.$$

对于样本 $S$，以至少 $1-\delta$ 的概率，所有 $f\in\mathcal{F}_{A,B}$ 同时满足

$$\mathbb{P}_{(\boldsymbol{x},y)\sim\mathcal{P}}\{yf(\boldsymbol{x})\leq 0\}\leq\frac{1}{n}\sum_{i=1}^{n}\mathbb{I}\{y_if(\boldsymbol{x}_i)\leq\gamma\}+\frac{4ABr}{\gamma\sqrt{n}}+3\sqrt{\frac{\log(2/\delta)}{2n}}. \tag{8.4}$$

这里把零间隔也计为错误，因此左侧同时控制采用任意固定平局规则时的零一损失期望风险。

**证明**　固定独立随机符号 $\sigma_i \in \{-1,+1\}$。输出权重的约束给出

$$\sup_{f\in\mathcal{F}_{A,B}} \sum_{i=1}^{n} \sigma_i f(\boldsymbol{x}_i) = A \sup_{\|\boldsymbol{w}\|_2 \le B} \left| \sum_{i=1}^{n} \sigma_i \phi(\boldsymbol{w}^\top \boldsymbol{x}_i) \right|.$$

绝对值可分别用正号与负号的上确界之和控制；由于 $\boldsymbol{w} = 0$ 可取，这两个上确界都非负。随机符号的对称性使它们的期望相同。再用 ReLU 的 1-Lipschitz 性质与收缩不等式，得到

$$\begin{aligned} \widehat{\mathfrak{R}}_S(\mathcal{F}_{A,B}) &\le \frac{2AB}{n} \mathbb{E}_\sigma \left\| \sum_{i=1}^{n} \sigma_i \boldsymbol{x}_i \right\|_2 \\ &\le \frac{2AB}{n} \sqrt{\sum_{i=1}^{n} \|\boldsymbol{x}_i\|_2^2} \le \frac{2ABr}{\sqrt{n}}. \end{aligned}$$

第二步使用 Jensen 不等式，交叉项因随机符号独立且均值为零而消失。

令斜坡损失 $\psi_\gamma(u)$ 在 $u \le 0$ 时为 1，在 $0 < u < \gamma$ 时为 $1 - u/\gamma$，在 $u \ge \gamma$ 时为 0。它上界零一错误指示函数，且为 $1/\gamma$-Lipschitz。固定样本标签后，$\sigma_i y_i$ 仍是独立随机符号，因此损失函数空间的经验 Rademacher 复杂度不超过 $\widehat{\mathfrak{R}}_S(\mathcal{F}_{A,B})/\gamma$。应用定理 5.7的经验复杂度形式，并用 $\psi_\gamma(y_i f(\boldsymbol{x}_i)) \le \mathbb{I}\{y_i f(\boldsymbol{x}_i) \le \gamma\}$，即得所述期望风险上界。 ■

隐藏宽度 $m$ 没有直接出现在右侧，所以固定 $A, B, r, \gamma$ 时，增宽不必提高充分样本门槛。增宽若同时使 $A, B$ 增长，或使更多样本间隔很小，界仍会变得宽松。宽度消失依赖于这些固定的约束。

因此，范数替代参数计数是一条有条件的分析。把 ReLU 输出权重乘以很小正数，分类符号不变，范数与间隔却一起缩小，式 (8.4)中的比值没有改善。仅压小原始范数不能控制无约束分类空间的 PAC 学习；定理直接提供的是指定间隔尺度下的风险保证。

我们可以把附加风险代价反解为样本门槛。给定 $\varepsilon > 0$，取

$$n \ge \frac{1}{\varepsilon^2} \left( \frac{4ABr}{\gamma} + 3\sqrt{\frac{\log(2/\delta)}{2}} \right)^2, \tag{8.5}$$

就使式 (8.4)在经验间隔错误率之外的两项不超过 $\varepsilon$。若训练输出有至多 $a$ 比例样本未达到 $\gamma$ 间隔，则以概率至少 $1-\delta$，零一风险不超过 $a + \varepsilon$。门槛控制样本评价到总体评价的附加代价，$a$ 能否降低仍取决于训练与数据。

减小范数与增大正确间隔都可改善这个上界，但单独压缩权重可能增加未达间隔的样本。范数—间隔比固定时，样本量增为四倍，附加误差界减半。这是充分界的缩放，既不保证实际测试错误减半，也不证明更少样本不能学习。

### 8.2.3 深层网络的谱复杂度

输入扰动在深层网络中逐层传播。谱范数 $\|\boldsymbol{W}\|_2$ 是单位向量经矩阵变换后的最大长度，所以各层谱范数相乘可控制整体放大；激活为 $a_\ell$-Lipschitz 时，还须乘相应因子。图 8.3沿同一输入变化展示这些乘积。后面采用 1-Lipschitz 激活，故激活因子为 1。

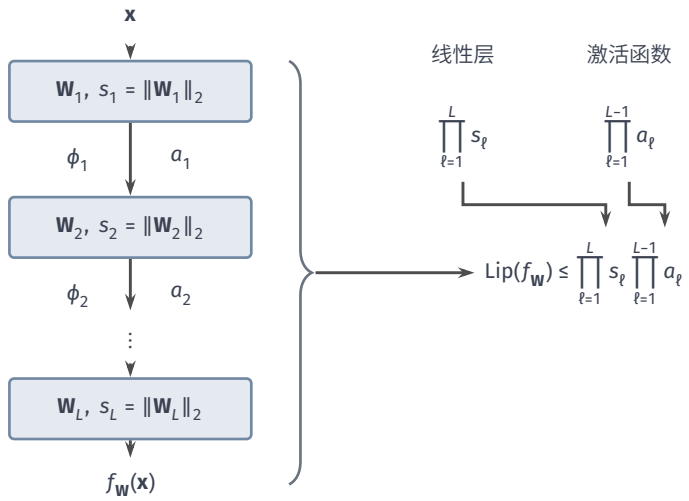


图 8.3　谱范数与激活函数共同控制输入扰动。第 $\ell$ 层线性变换至多放大 $s_\ell = \|\boldsymbol{W}_\ell\|_2$ 倍，层间激活再至多放大 $a_\ell$ 倍；末层为线性输出。右上方两类因子分别连到乘积上界，大括号归并各层作用。当激活均为 1-Lipschitz 时，只剩谱范数乘积；该乘积仍不是完整的泛化复杂度。

放大上界还不是函数复杂度。同一谱范数可以对应许多不同矩阵，因此我们还要控制指定近似精度下区分这些函数所需的数量。

为记录各层矩阵的这种约束，沿用行分组范数 $\|\boldsymbol{A}\|_{2,1} = \sum_i \|\boldsymbol{A}_{i,:}\|_2$。对无偏置、1-Lipschitz 且零点为零的激活网络，Bartlett、Foster 与 Telgarsky 在参考矩阵为零时使用

$$\mathcal{C}(\boldsymbol{W}) = \left(\prod_{\ell=1}^{L} \|\boldsymbol{W}_\ell\|_2\right)\left[\sum_{\ell=1}^{L}\left(\frac{\|\boldsymbol{W}_\ell\|_{2,1}}{\|\boldsymbol{W}_\ell\|_2}\right)^{2/3}\right]^{3/2}. \tag{8.6}$$

乘积控制传播，混合范数项参与函数近似的计数。这里按各谱范数非零书写，零矩阵层另行处理。下面采用事先固定范数上限的版本，把这个量接到样本量与风险[6]。

[6] P. L. Bartlett, D. J. Foster, M. J. Telgarsky, *Spectrally-Normalized Margin Bounds for Neural Networks* In Advances in Neural Information Processing Systems 30, 2017

**定理 8.4　深层网络的谱复杂度与期望风险**　设 $n, L \geq 1$，固定维数 $d_0, \dots, d_L \leq w$ 且 $d_L \geq 2$，输入空间 $X \subseteq \mathbb{R}^{d_0}$ 取 Borel $\sigma$ 代数，标签空间 $Y = \{1, \dots, d_L\}$。对 $\boldsymbol{W}_\ell \in \mathbb{R}^{d_\ell \times d_{\ell-1}}$，定义无偏置网络

$$\begin{aligned} \boldsymbol{h}_0(\boldsymbol{x}) &= \boldsymbol{x}, \\ \boldsymbol{h}_\ell(\boldsymbol{x}) &= \phi_\ell(\boldsymbol{W}_\ell \boldsymbol{h}_{\ell-1}(\boldsymbol{x})), \qquad 1 \leq \ell < L, \\ f_{\boldsymbol{W}}(\boldsymbol{x}) &= \boldsymbol{W}_L \boldsymbol{h}_{L-1}(\boldsymbol{x}). \end{aligned}$$

其中各 $\phi_\ell$ 固定、逐坐标作用、为 1-Lipschitz 且在零点为零。定义

$$\operatorname{margin}_{\boldsymbol{W}}(\boldsymbol{x}, y) = f_{\boldsymbol{W}}(\boldsymbol{x})_y - \max_{j \neq y} f_{\boldsymbol{W}}(\boldsymbol{x})_j.$$

对任意矩阵 $\boldsymbol{A}$，记 $\|\boldsymbol{A}\|_{2,1} = \sum_i \|\boldsymbol{A}_{i,:}\|_2$。设 $\mathcal{P}$ 为 $X \times Y$ 上的概率分布，$S = ((\boldsymbol{x}_1, y_1), \dots, (\boldsymbol{x}_n, y_n)) \sim \mathcal{P}^n$，并令

$$R^{01}(\boldsymbol{W}) = \mathbb{P}_{(\boldsymbol{x},y)\sim\mathcal{P}}\{\text{固定平局规则下} f_{\boldsymbol{W}} \text{ 的预测不等于} y\}.$$

在抽样前固定 $r, \gamma, s_\ell, b_\ell > 0$ 及 $\delta \in (0,1)$，并令

$$\mathcal{C}_0 = \left( \prod_{\ell=1}^{L} s_\ell \right) \left[ \sum_{\ell=1}^{L} (b_\ell / s_\ell)^{2/3} \right]^{3/2}.$$

若 $\|\boldsymbol{x}\|_2 \leq r$ 在 $\mathcal{P}$ 下几乎处处成立且 $n \geq 2$，则以至少 $1-\delta$ 的概率，所有满足 $\|\boldsymbol{W}_\ell\|_2 \leq s_\ell$、$\|\boldsymbol{W}_\ell\|_{2,1} \leq b_\ell$ 的网络同时有

$$\begin{aligned} R^{01}(\boldsymbol{W}) \leq \hat{R}_{S,\gamma}(\boldsymbol{W}) &+ \frac{8}{n} \\ &+ \frac{72 r \mathcal{C}_0 \log(2w) \log n}{\gamma \sqrt{n}} + 3\sqrt{\frac{\log(1/\delta)}{2n}}, \end{aligned} \tag{8.7}$$

其中 $\hat{R}_{S,\gamma} = n^{-1} \sum_i \mathbb{I}\{\operatorname{margin}_{\boldsymbol{W}}(\boldsymbol{x}_i, y_i) \leq \gamma\}$ 为经验间隔错误率，预测使用固定的平局规则。

**证明**　采用 Bartlett 等论文附录引理 A.8 的固定范数约束界。该引理的复杂度项为 $72\|\boldsymbol{X}\|_F \mathcal{C}_0 \log(2w) \log n / (\gamma n)$，其中 $\boldsymbol{X}$ 的各行为输入样本。由 $\|\boldsymbol{x}_i\|_2 \leq r$ 可得 $\|\boldsymbol{X}\|_F \leq r\sqrt{n}$，代入便得到所述形式。这里使用了外部引理中的网络覆盖数估计，不把该组合估计视为已在本章证明。 ∎

上界在经验间隔错误率外保留三项余量。指定附加误差 $\varepsilon > 0$ 后，选 $n$ 使

$$\frac{8}{n} + \frac{72 r \mathcal{C}_0 \log(2w) \log n}{\gamma \sqrt{n}} + 3\sqrt{\frac{\log(1/\delta)}{2n}} \le \varepsilon,$$

即可得到概率至少 $1-\delta$ 的 $R^{01}(\boldsymbol{W}) \le \hat{R}_{S,\gamma}(\boldsymbol{W}) + \varepsilon$。这是一条可逐个试代 $n$ 的充分条件；忽略对数因子，门槛为 $\big((r\mathcal{C}_0/\gamma)^2 + \log(1/\delta)\big)/\varepsilon^2$ 量级。深度和宽度仍通过 $\mathcal{C}_0$ 及对数参与，因此只替代了粗略参数计数，没有消除结构影响。

固定输入尺度、间隔尺度，并比较经验间隔错误率相近的网络，较小谱复杂度给出较小风险上界。复杂度项主导且忽略对数变化时，$\mathcal{C}_0/\gamma$ 减半可将同一附加误差的充分样本量约降为四分之一。然而，上界较小不证明实际错误率较低；上界大于 1 时尚不能提供非平凡分类保证。经验间隔分布与复杂度需要共同观察。

范数上限与间隔尺度在这条定理中必须先于样本固定。若训练后再选择它们，应对多组约束同时建立保证，或采用文献中的自适应版本，并加入额外对数项。不能直接把事后测量值代入固定约束而遗漏选择代价。

ReLU 的正齐次性使相邻层乘 $c > 0$ 与除 $c$ 保留同一函数。谱范数乘积与混合范数比也保留，因此这一复杂度不会将这种等价表示判为不同分类能力。它同时结合范数约束和经验间隔评价。

Schatten 范数（Schatten norm）按奇异值的 $p$ 范数（$1 \le p \le \infty$）汇总矩阵的谱规模；非零矩阵的稳定秩则用总平方谱能量除以最大奇异值平方，零矩阵另约定为零。这些量与依赖坐标的行分组量不同（可参考第一卷“线性空间”章的 Schatten 范数定义及同章的稳定秩定义）。不同风险界使用不同谱量，式 (8.6)采用的是行分组比值，不能直接换成稳定秩。

同一传播机制还可以连接参数稳定性，但比较对象要换成相邻样本的两次训练。若第 $\ell$ 层变化至多 $\alpha_{\ell,n}$，这一变化经后续层传递到输出。各层范数因而负责控制放大，下面把它与实际参数变化同时列出。

**定理 8.5　分层参数稳定性与期望泛化差**　设 $n, L \ge 1$，$(X, \mathcal{X})$ 为 $\mathbb{R}^{d_0}$ 的可测子空间，$(Y, \mathcal{Y})$ 为标签空间，$\mathcal{P}$ 为 $X \times Y$ 上的概率分布，且 $S = ((\boldsymbol{x}_1, y_1), \dots, (\boldsymbol{x}_n, y_n)) \sim \mathcal{P}^n$。固定维数 $d_0, \dots, d_L$；对 $\boldsymbol{W}_\ell \in \mathbb{R}^{d_\ell \times d_{\ell-1}}$，定义无偏置网络

$$\begin{aligned} \boldsymbol{h}_0(\boldsymbol{x}) &= \boldsymbol{x}, \\ \boldsymbol{h}_\ell(\boldsymbol{x}) &= \phi_\ell(\boldsymbol{W}_\ell \boldsymbol{h}_{\ell-1}(\boldsymbol{x})), \qquad 1 \le \ell < L, \\ f_{\boldsymbol{W}}(\boldsymbol{x}) &= \boldsymbol{W}_L \boldsymbol{h}_{L-1}(\boldsymbol{x}). \end{aligned}$$

各 $\phi_\ell$ 固定、可测、逐坐标作用、为 1-Lipschitz 且在零点为零，并且 $\|\boldsymbol{x}\|_2 \le r$ 对所有 $\boldsymbol{x} \in X$ 成立。设可测确定性算法 $A$ 对任意仅有一个观测不同的相邻样本 $S, S'$ 输出 $\boldsymbol{W} = A(S)$、$\boldsymbol{W}' = A(S')$，且每层均满足 $\|\boldsymbol{W}_\ell\|_2, \|\boldsymbol{W}'_\ell\|_2 \le s_\ell$，并有 $\|\boldsymbol{W}_\ell - \boldsymbol{W}'_\ell\|_2 \le \alpha_{\ell,n}$。设预测损失 $\ell_{\text{pred}} : \mathbb{R}^{d_L} \times Y \to \mathbb{R}$ 可测，并且对所有 $y \in Y$ 和 $\boldsymbol{u}, \boldsymbol{v} \in \mathbb{R}^{d_L}$ 都有

$$|\ell_{\text{pred}}(\boldsymbol{u}, y) - \ell_{\text{pred}}(\boldsymbol{v}, y)| \le G\|\boldsymbol{u} - \boldsymbol{v}\|_2,$$

其中 $r, G, s_\ell, \alpha_{\ell,n} \ge 0$，且 $\mathbb{E}_{y\sim\mathcal{P}_Y}|\ell_{\text{pred}}(\mathbf{0}, y)| < \infty$。定义

$$R(\boldsymbol{W}) = \mathbb{E}_{(\boldsymbol{x},y)\sim\mathcal{P}}\ell_{\text{pred}}(f_{\boldsymbol{W}}(\boldsymbol{x}), y),$$
$$\hat{R}_S(\boldsymbol{W}) = \frac{1}{n}\sum_{i=1}^{n}\ell_{\text{pred}}(f_{\boldsymbol{W}}(\boldsymbol{x}_i), y_i).$$

则

$$\left|\mathbb{E}_S\left[R(A(S)) - \hat{R}_S(A(S))\right]\right| \le Gr\sum_{\ell=1}^{L}\alpha_{\ell,n}\prod_{j\ne\ell}s_j.$$

**证明**　从 $\boldsymbol{W}$ 出发，逐层把权重替换成 $\boldsymbol{W}'$ 中的对应权重。只替换第 $\ell$ 层时，该层输入的范数不超过 $r\prod_{j<\ell}s_j$；本层产生的变化再经过后续各层，输出差至多为 $r\alpha_{\ell,n}\prod_{j\ne\ell}s_j$。把各次替换的输出差相加，再乘损失的 Lipschitz 常数，便得到损失均匀稳定性上界。输出范数至多为 $r\prod_j s_j$，所以零输出处的可积性与 Lipschitz 条件也保证测试损失和训练损失可积。由定理 7.10得到期望泛化差结论。 ■

右侧同时需要 $s_j$ 和 $\alpha_{\ell,n}$：前者限制放大，后者限制样本替换带来的变化。单有范数界只知 $\alpha_{\ell,n} \le 2s_\ell$，不足以使泛化差随 $n$ 消失。结论还针对 Lipschitz 损失，零一损失必须另外借助间隔连接。谱复杂度沿一致收敛控制函数空间，这里则沿稳定性控制实际算法，网络结构相似而条件不同。

## 8.3　基于参数梯度初始值的可学习性

范数分析没有解释训练怎样选到受控函数。我们先考察一种可解情形：训练改变了输出，却几乎保留了输出对参数的局部敏感方向。初始梯度于是成为近似固定特征，在这一近似中，训练转为特征上的线性学习。

具体地，将输入映射为 $\boldsymbol{\varphi}_0(\boldsymbol{x}) = \nabla_\theta f_{\theta^{(0)}}(\boldsymbol{x})$。每个坐标记录轻微调整某个初始参数时该输入的分数变化，而不是原图像坐标。输入的相似性由这些响应方向比较。某些无限宽极限可让这组特征在训练中保持有效，从而允许核方法的风险分析。

这一路径需要依次说明三件事：初始梯度给出哪些特征，训练在特征空间选择哪个函数，这个函数的再生核空间范数和数据分布如何控制风险。训练拟合或核矩阵正定只完成其中部分工作，不能代替选解与泛化。

### 8.3.1 初始梯度与特征空间

为了固定近似对象，考虑 $p$ 参数标量网络，记初始函数 $f_0 = f_{\theta^{(0)}}$。初始化附近的一阶展开为

$$f_\theta(\boldsymbol{x}) \approx f_0(\boldsymbol{x}) + \langle \boldsymbol{\varphi}_0(\boldsymbol{x}), \boldsymbol{v} \rangle, \qquad \boldsymbol{v} = \theta - \theta^{(0)}. \tag{8.8}$$

它将参数增量映射为函数增量。图 8.4在一个两参数教学网络中，沿实际轨迹比较真实输出、一阶输出及其差值。切空间属于输出或函数空间：初始梯度将 $\boldsymbol{v}$ 映射为 $x \mapsto \langle \boldsymbol{\varphi}_0(x), \boldsymbol{v} \rangle$，并非在参数平面任取投影得到。

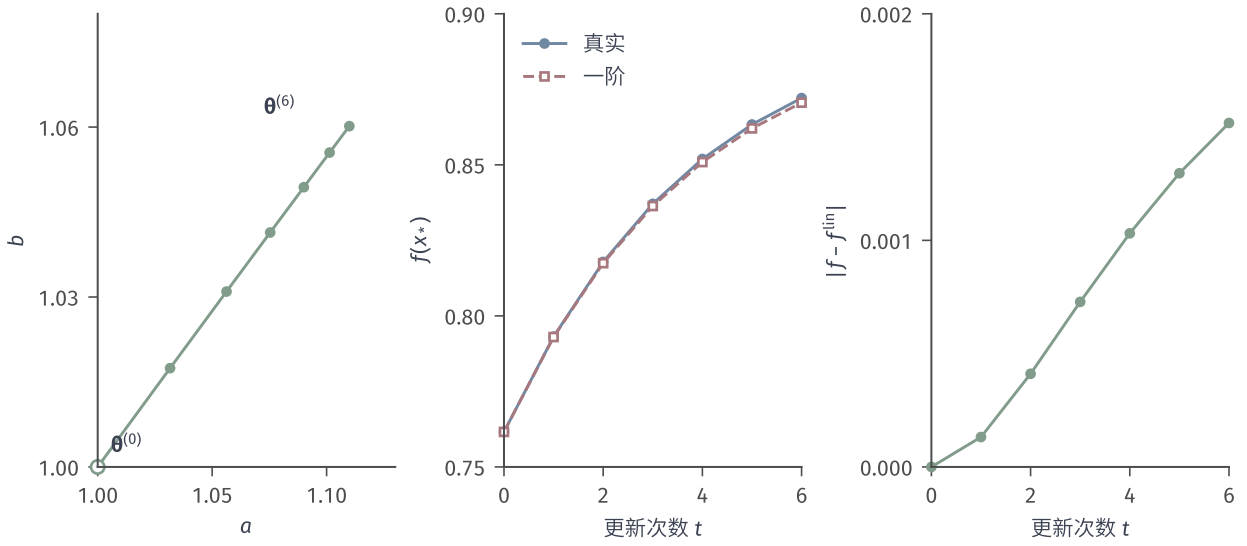


图 8.4 初始化附近的参数轨迹与输出线性化。教学网络为 $f_{(a,b)}(x) = a\tanh(bx)$，初值为 $(1,1)^\top$；用单个样本 $(x,y) = (1, 0.9)$ 的半平方损失、步长 0.3 执行六次梯度下降，连同初值共七个检查点。中间的真实输出和一阶输出均在左侧同一参数轨迹上计算；三面板绘图区大小相同，参数、输出和绝对余项各用所标坐标范围，不能按纸面高度直接比较数值。右侧余项末次约为 0.00152。近初始化时二者接近，但余项并非零。参数增量经初始雅可比映射到输出／函数空间的切空间；NTK 是初始梯度在不同输入上的内积。此有限网络示例展示近似对象，不证明训练中核恒定或新输入上的误差受控。

在线性化模型中，训练只改变系数 $\boldsymbol{v}$，输入特征保持为 $\boldsymbol{\varphi}_0(\boldsymbol{x})$。这个特征由网络和初始化决定，通常不是末层激活，也不是经验风险梯度。输出梯度只依赖输入，经验风险梯度还包含标签与当前预测误差。

从 $\boldsymbol{v} = 0$ 开始，每次经验风险梯度都是训练特征的线性组合，所以更新留在 $\mathrm{span}\{\boldsymbol{\varphi}_0(\boldsymbol{x}_1), \dots, \boldsymbol{\varphi}_0(\boldsymbol{x}_n)\}$。新输入的特征可以不在这个子空间，但它与训练特征的内积决定所学更新怎样影响预测。为表达这一传递关系，我们定义梯度内积对应的核。

**定义 8.6 神经切线核** 设网络输出对参数可微。参数为 $\theta$ 时的神经切线核（neural tangent kernel, NTK）为

$$K_\theta(\boldsymbol{x}, \boldsymbol{x}') = \left\langle \nabla_\theta f_\theta(\boldsymbol{x}), \nabla_\theta f_\theta(\boldsymbol{x}') \right\rangle .$$

记 $K_0 = K_{\theta^{(0)}}$，其在 $n$ 个训练输入上的核矩阵为 $\boldsymbol{K}_0$，其中 $(\boldsymbol{K}_0)_{i,j} = K_0(\boldsymbol{x}_i, \boldsymbol{x}_j)$。

核值可以直接计算一次训练的传播。若用样本 $i$ 更新，损失对当前分数的导数为 $a_i$，在线性化模型中

$$\Delta \boldsymbol{v} = -\eta a_i \boldsymbol{\varphi}_0(\boldsymbol{x}_i), \qquad \Delta f(\boldsymbol{x}_j) = -\eta a_i K_0(\boldsymbol{x}_j, \boldsymbol{x}_i).$$

初始梯度方向相似时，一个输入的训练可能改变另一个的预测；正交时，此次更新对另一输入的分数没有影响。这个结论只描述当前固定特征下的信息传递。

图 8.5将同一次更新分成两步：训练输入的梯度产生参数增量，另一输入的输出梯度将增量转换为预测变化。两份梯度都针对网络输出与参数的关系，区别于末层表示和整份经验风险梯度。

Jacot 等在特定参数化、初始化和无限宽极限下得到确定核，并在相应训练条件下证明它保持不变[7]。网络由固定梯度特征描述时，常称为**惰性训练**（lazy training）。宽度趋于无穷还需指定缩放，另一种缩放可得到持续变化的特征。有限宽应用必须检查核变化与线性化余项；ReLU 导数只在可微点直接使用，不可微点还需约定。

[7] A. Jacot, F. Gabriel, C. Hongler, *Neural Tangent Kernel: Convergence and Generalization in Neural Networks* In Advances in Neural Information Processing Systems, 2018

### 8.3.2 核矩阵与训练结果

我们先用半平方损失计算训练输入上的变化。令 $\boldsymbol{f}(t)$ 和 $\boldsymbol{y}$ 分别为预测与标签向量，链式法则给出真实网络梯度流

$$\dot{\boldsymbol{f}}(t) = -\frac{1}{n} \boldsymbol{K}_{\theta(t)} (\boldsymbol{f}(t) - \boldsymbol{y}).$$

固定核模型将时间变化的矩阵换为 $\boldsymbol{K}_0$，于是可以在各特征方向上求解。连续时间在此简化机制说明，离散更新还须检查步长。

**定理 8.7 固定 NTK 下的训练收敛** 设 $n \geq 1$，$\boldsymbol{K}_0 \in \mathbb{R}^{n \times n}$ 为正定矩阵，最小特征值为 $\lambda_{\min} > 0$，并给定 $\boldsymbol{y}, \boldsymbol{f}(0) \in \mathbb{R}^n$。若 $\dot{\boldsymbol{f}}(t) = -\boldsymbol{K}_0(\boldsymbol{f}(t) - \boldsymbol{y})/n$，则

$$\boldsymbol{f}(t) - \boldsymbol{y} = e^{-\boldsymbol{K}_0 t/n} (\boldsymbol{f}(0) - \boldsymbol{y}),$$

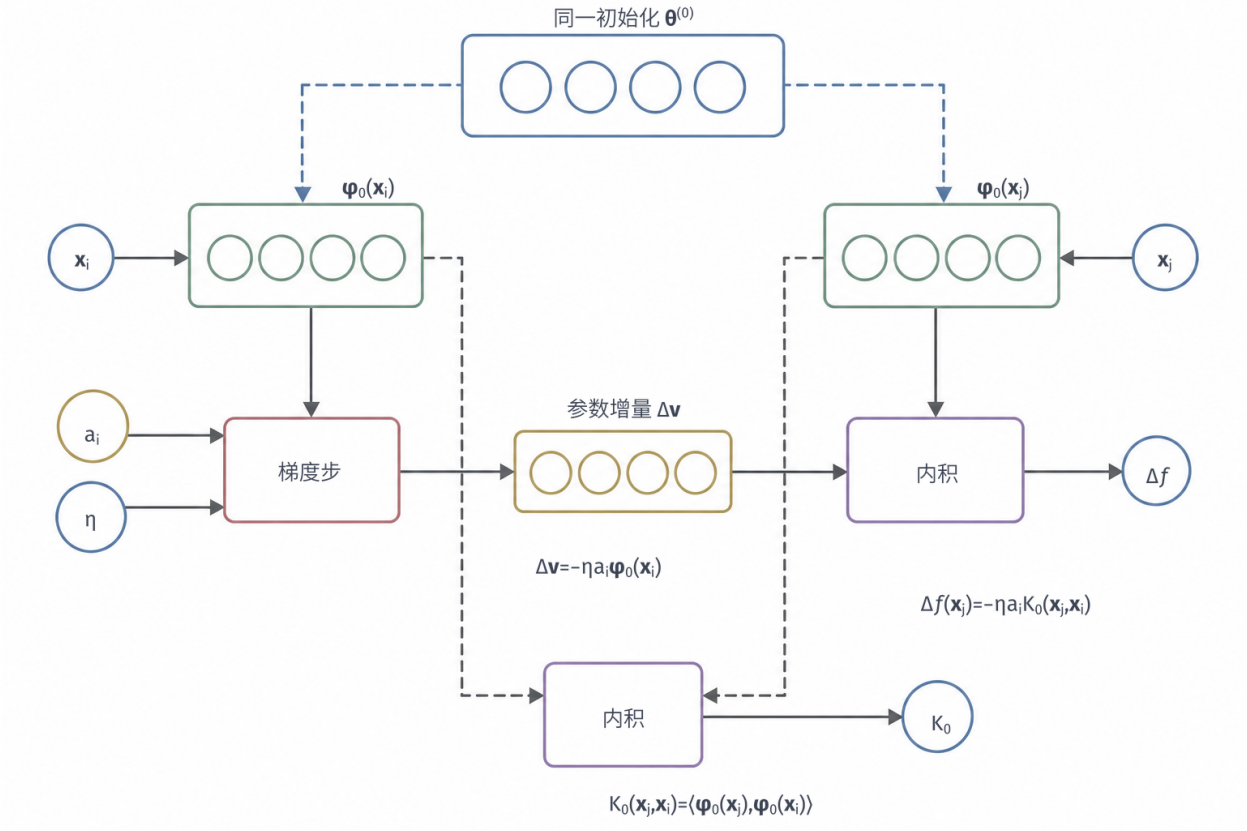


图 8.5 初始梯度特征如何传递一次训练更新。在线性化模型中，样本 $i$ 的梯度特征与损失对预测的导数 $a_i$ 共同确定参数增量 $\Delta \boldsymbol{v}$；将同一增量与样本 $j$ 的梯度特征作内积，得到 $\Delta f(\boldsymbol{x}_j)$。核值 $K_0$ 正是两个初始梯度特征的内积。蓝色虚线把两份梯度关联到同一初始化，深色虚线展示核内积所用的两份梯度。特征条仅示意梯度坐标，不限定参数维数。对真实有限宽网络使用固定特征，还需控制核变化与线性化误差。

并有 $\|\boldsymbol{f}(t)-\boldsymbol{y}\|_2 \le e^{-\lambda_{\min} t/n}\|\boldsymbol{f}(0)-\boldsymbol{y}\|_2$。

**证明** 将 $\boldsymbol{K}_0$ 正交对角化。特征值 $\lambda_j$ 对应的残差分量满足

$$\dot{e}_j(t) = -\lambda_j e_j(t)/n, \qquad e_j(t) = e^{-\lambda_j t/n} e_j(0).$$

合并各方向即得矩阵指数表达式，再用 $\lambda_j \ge \lambda_{\min}$ 控制欧氏范数。 ■

各核特征方向按对应特征值衰减：大特征值方向学得快，小特征值方向学得慢。相同训练时长下，标签在这些方向上的分量会改变经验误差。这个结论仅评价训练输入，下一步还要确定最终函数及其表示范数，才能分析新输入。

### 8.3.3 再生核空间与期望风险

训练预测相同的函数可能来自不同参数位移，其中一些方向完全不改变输出。直接取某个参数向量的范数会计入这些冗余。固定核方法对所有表示取最小系数范数，从而将复杂度归到函数而不是任意表示。

由 $K_0$ 生成的**再生核希尔伯特空间**（reproducing kernel Hilbert space, RKHS）记为 $\mathcal{H}_{K_0}$。在 $\mathcal{H}_{K_0}$ 中，固定位置 $\boldsymbol{x}$ 的核截面 $K_0(\boldsymbol{x},\cdot)$ 与函数的内积给出该函数在 $\boldsymbol{x}$ 处的值；函数差的空间范数因而能够控制该位置的预测差异（可参考第一卷“函数空间”章的再生核 Hilbert 空间定义）。在有限维梯度特征下，它包含 $g(\boldsymbol{x})=\langle \boldsymbol{v},\boldsymbol{\varphi}_0(\boldsymbol{x})\rangle$，并以

$$\|g\|_{\mathcal{H}_{K_0}}=\inf\{\|\boldsymbol{v}\|_2 : g(\boldsymbol{x})=\langle \boldsymbol{v},\boldsymbol{\varphi}_0(\boldsymbol{x})\rangle \text{ 对所有}\boldsymbol{x}\text{ 成立}\}$$

计算函数复杂度。下确界排除了不影响函数的系数方向。我们控制的是相对于初始化的变化 $g=f-f_0$，而非默认 $f_0=0$ 后的整个输出。

为了拟合标签，应先减去初始预测，得到 $r_i=y_i-f_0(\boldsymbol{x}_i)$ 和 $\boldsymbol{r}=(r_1,\dots,r_n)^\top$。从零参数位移出发，固定特征平方损失的梯度流在插值函数中选择最小 RKHS 范数者。下面将这个选解及其范数一起求出。

**定理 8.8　初始梯度特征的最小范数插值**　设 $X$ 为非空集合，$K_0:X\times X\to\mathbb{R}$ 为正定核，$\mathcal{H}_{K_0}$ 为其 RKHS。给定 $n\ge 1$ 个输入 $\boldsymbol{x}_1,\dots,\boldsymbol{x}_n\in X$、实数标签 $y_1,\dots,y_n$ 和函数 $f_0:X\to\mathbb{R}$，定义

$$(\boldsymbol{K}_0)_{i,j}=K_0(\boldsymbol{x}_i,\boldsymbol{x}_j),\qquad r_i=y_i-f_0(\boldsymbol{x}_i),\qquad \boldsymbol{r}=(r_1,\dots,r_n)^\top.$$

假设核矩阵 $\boldsymbol{K}_0$ 正定，并令 $\boldsymbol{k}_0(\boldsymbol{x})=(K_0(\boldsymbol{x}_i,\boldsymbol{x}))_{i=1}^n$。满足 $g(\boldsymbol{x}_i)=r_i$ 的最小 RKHS 范数函数为

$$\hat{g}(\boldsymbol{x})=\boldsymbol{k}_0(\boldsymbol{x})^\top\boldsymbol{K}_0^{-1}\boldsymbol{r},$$

其范数满足

$$\|\hat{g}\|_{\mathcal{H}_{K_0}}^2=\boldsymbol{r}^\top\boldsymbol{K}_0^{-1}\boldsymbol{r}=\sum_{j=1}^{n}\frac{(\boldsymbol{u}_j^\top\boldsymbol{r})^2}{\lambda_j},\tag{8.9}$$

其中 $(\lambda_j,\boldsymbol{u}_j)$ 为 $\boldsymbol{K}_0$ 的正交特征对。定义半平方经验损失

$$\mathcal{E}(g)=\frac{1}{2n}\sum_{i=1}^{n}\bigl(f_0(\boldsymbol{x}_i)+g(\boldsymbol{x}_i)-y_i\bigr)^2.$$

对 $\mathcal{E}$ 从 $g_0 = 0$ 出发的 RKHS 梯度流

$$\dot{g}_t = -\frac{1}{n}\sum_{i=1}^{n}(f_0(\boldsymbol{x}_i) + g_t(\boldsymbol{x}_i) - y_i)K_0(\boldsymbol{x}_i, \cdot)$$

收敛到 $\hat{g}$。

**证明** 将任意 $g$ 分解为 $\mathrm{span}\{K_0(\boldsymbol{x}_i, \cdot)\}_{i=1}^n$ 中的分量与正交分量。由再生性质，正交分量在所有训练输入上取值为零，去掉它不改变插值条件，却不会增大范数。最小范数函数因而形如 $g = \sum_i a_i K_0(\boldsymbol{x}_i, \cdot)$。插值条件为 $\boldsymbol{K}_0\boldsymbol{a} = \boldsymbol{r}$，故 $\boldsymbol{a} = \boldsymbol{K}_0^{-1}\boldsymbol{r}$，且 $\|g\|^2 = \boldsymbol{a}^\top \boldsymbol{K}_0 \boldsymbol{a} = \boldsymbol{r}^\top \boldsymbol{K}_0^{-1}\boldsymbol{r}$。对核矩阵作谱分解得到第二个等式。梯度流始终留在上述张成空间中，训练收敛定理又保证插值，因此只能收敛到这个唯一的插值函数。 ■

式 (8.9)按核特征方向计算插值代价。小特征值只有遇到非零标签分量才增加范数。取

$$\boldsymbol{K}_0 = \begin{pmatrix} 1 & 1-a \\ 1-a & 1 \end{pmatrix}, \qquad 0 < a \le 1,$$

其特征值为 $2-a$ 和 $a$。残余标签同为 1 时，范数平方为 $2/(2-a)$；标签为 1 和 $-1$ 时，却为 $2/a$。$a$ 小时，初始梯度将两输入判为相似，强制相反输出便需要较大范数。核不变而标签方向改变，就足以改变复杂度及其风险界。

要把这一范数接到总体风险，我们固定独立于样本的核，并要求 $K_0(\boldsymbol{x}, \boldsymbol{x}) \le \kappa^2$，即梯度特征范数至多 $\kappa$。再事先指定 $B$，分析 $\mathcal{G}_B = \{g \in \mathcal{H}_{K_0} : \|g\|_{\mathcal{H}_{K_0}} \le B\}$ 的 Rademacher 复杂度。

**定理 8.9 初始梯度特征的期望风险界** 设 $(X, \mathcal{X})$ 为可测输入空间，$Y \subseteq \mathbb{R}$ 为可测标签空间，$\mathcal{P}$ 为 $X \times Y$ 上的概率分布，且 $S = ((\boldsymbol{x}_1, y_1), \dots, (\boldsymbol{x}_n, y_n)) \sim \mathcal{P}^n$。函数 $f_0 : X \to \mathbb{R}$ 与可测正定核 $K_0 : X \times X \to \mathbb{R}$ 在抽样前确定；它们也可随机选取，但须与 $S$ 独立，并且以下条件几乎必然成立。令 $\mathcal{H}_{K_0}$ 为 $K_0$ 的 RKHS，假设 $K_0(\boldsymbol{x}, \boldsymbol{x}) \le \kappa^2$ 对所有 $\boldsymbol{x} \in X$ 成立，并定义

$$\mathcal{G}_B = \{g \in \mathcal{H}_{K_0} : \|g\|_{\mathcal{H}_{K_0}} \le B\}.$$

损失 $\ell : \mathbb{R} \times Y \to [0,1]$ 可测，且关于第一个变量为 $G$-Lipschitz。对任意可测 $f : X \to \mathbb{R}$，定义

$$R(f) = \mathbb{E}_{(\boldsymbol{x},y)\sim\mathcal{P}}\ell(f(\boldsymbol{x}),y), \qquad \hat{R}_S(f) = \frac{1}{n}\sum_{i=1}^{n}\ell(f(\boldsymbol{x}_i),y_i).$$

假设随机变量 $\sup_{g\in\mathcal{G}_B}|R(f_0+g)-\hat{R}_S(f_0+g)|$ 可测。对任意在抽样前固定的 $B,\kappa,G>0$ 和 $\delta\in(0,1)$，以概率至少 $1-\delta$，对所有 $g\in\mathcal{G}_B$ 同时有

$$R(f_0+g) \le \hat{R}_S(f_0+g) + \frac{2G\kappa B}{\sqrt{n}} + 3\sqrt{\frac{\log(2/\delta)}{2n}}. \tag{8.10}$$

若存在 $g_\star \in \mathcal{G}_B$ 使 $y = f_0(\boldsymbol{x}) + g_\star(\boldsymbol{x})$ 在 $\mathcal{P}$ 下几乎处处成立，且 $\ell(y,y)=0$，并且样本核矩阵 $\boldsymbol{K}_0 = (K_0(\boldsymbol{x}_i,\boldsymbol{x}_j))_{i,j=1}^n$ 几乎必然正定，则定义

$$\hat{g} \in \arg\min_{g\in\mathcal{H}_{K_0}} \left\{ \|g\|_{\mathcal{H}_{K_0}} : f_0(\boldsymbol{x}_i)+g(\boldsymbol{x}_i)=y_i,\ 1\le i\le n \right\}.$$

最小范数插值函数 $\hat{g}$ 满足同一上界且经验风险项为零。对任意 $\varepsilon\in(0,1)$，一个充分样本量条件是

$$n \ge \max\left\{ \frac{16G^2\kappa^2B^2}{\varepsilon^2}, \frac{18\log(2/\delta)}{\varepsilon^2} \right\},$$

此时期望风险以概率至少 $1-\delta$ 不超过 $\varepsilon$。

**证明**　利用再生性质、Cauchy–Schwarz 不等式以及独立随机正负号的交叉项期望为零，得到

$$\begin{aligned}\hat{\mathfrak{R}}_S(\mathcal{G}_B) &= \frac{B}{n}\mathbb{E}_\sigma\left\|\sum_{i=1}^{n}\sigma_i K_0(\boldsymbol{x}_i,\cdot)\right\|_{\mathcal{H}_{K_0}} \\ &\le \frac{B}{n}\sqrt{\sum_{i=1}^{n}K_0(\boldsymbol{x}_i,\boldsymbol{x}_i)} \le \frac{\kappa B}{\sqrt{n}}.\end{aligned}$$

固定 $f_0$ 产生的偏移与所选函数无关，故不改变上述复杂度。再由损失的 Lipschitz 收缩性质引入因子 $G$，应用有界损失的期望风险界，即得式 (8.10)。

可实现函数 $g_\star$ 满足所有插值条件，所以最小范数解满足 $\|\hat{g}\| \le \|g_\star\| \le B$，且经验风险为零。分别使风险界两项至多 $\varepsilon/2$，就得到所列充分样本量。 ■

保证依赖小范数的目标表示、有界核对角、独立同分布抽样，以及训练达到对应插值解。即使特征无限多，也可以由 $\kappa B$ 控制复杂度；坐标数量在这里没有单独决定风险。

谱与标签也可共同验证范数条件。在同一高概率事件上，$\sum_j (\boldsymbol{u}_j^\top \boldsymbol{r})^2/\lambda_j \le B^2$ 就说明插值解属于所控空间。若这项条件另以概率至少 $1-\delta_0$ 成立，联合失败概率至多 $\delta+\delta_0$。$B$ 必须事先固定；观察后令 $B=\|\hat{g}\|$，需对一列预定范数球同时控制，而不能直接沿用原置信度。

核正定、即 $\lambda_{\min}(\boldsymbol{K}_0)>0$，只保证能够插值，不能替代小范数条件。粗略界 $\boldsymbol{r}^\top \boldsymbol{K}_0^{-1}\boldsymbol{r} \le \|\boldsymbol{r}\|_2^2/\lambda_{\min}$ 中，如果标签平方和 $\|\boldsymbol{r}\|_2^2$ 按 $n$ 增长而最小特征值只保持常数，复杂度项未必下降。Arora 等对特定两层过参数化网络的分析同时使用标签与核谱，并在明确初始化、宽度和数据条件下得到训练及不显含宽度的样本复杂度保证[8]。

[8] S. Arora, S. S. Du, W. Hu, Z. Li, R. Wang, *Fine-Grained Analysis of Optimization and Generalization for Overparameterized Two-Layer Neural Networks* In Proceedings of the 36th International Conference on Machine Learning, 2019, pp. 322–332

同一范数也可以经 PAC–Bayes 进入风险。对有界损失，将训练后后验与独立于样本的先验比较，相对熵记录后验偏离先验的代价，并与经验风险一起控制随机预测的总体风险（可参考第一卷“概率分布”章的“数据依赖下的同时风险控制”一节）。网络随机预测器版本见第 8.5.3节。对有限维位移，事先取 $P_0=\mathcal{N}(0,s^2\boldsymbol{I}_p)$、$s>0$，再以 $Q=\mathcal{N}(\hat{\boldsymbol{v}},s^2\boldsymbol{I}_p)$ 描述训练中心附近参数。相对熵为 $\|\hat{\boldsymbol{v}}\|_2^2/(2s^2)$。将定理 8.19与 Lipschitz 性合并，以概率至少 $1-\delta$，所有中心同时有

$$R(g_{\hat{\boldsymbol{v}}}) \le \hat{R}_S(g_{\hat{\boldsymbol{v}}}) + 2Gs\kappa + \sqrt{\frac{\|\hat{\boldsymbol{v}}\|_2^2/(2s^2)+\log((n+1)/\delta)}{2n}}, \tag{8.11}$$

其中 $g_{\boldsymbol{v}}=f_0+\langle \boldsymbol{v},\boldsymbol{\varphi}_0\rangle$。投影扰动 $\langle \boldsymbol{v}-\hat{\boldsymbol{v}},\boldsymbol{\varphi}_0(\boldsymbol{x})\rangle$ 的绝对值期望至多 $s\kappa$，把随机预测的经验与总体风险分别转回中心各付出 $Gs\kappa$。最小范数表示满足 $\|\hat{\boldsymbol{v}}\|_2^2=\|\hat{g}\|_{\mathcal{H}_{K_0}}^2$，因此同一核谱量出现在信息代价中。

PAC–Bayes 增加了扰动—相对熵的取舍：增大 $s$ 减小信息代价，却增加扰动损失。若插值范数统一有界，预先取 $s_n=n^{-1/4}$ 可使两项下降，但这个简单构造可能比 Rademacher 界慢。各向同性高斯只在有限维参数空间直接可用；无限维 RKHS 不能假设存在协方差 $s^2 I$ 的同类概率分布，仍可采用前面的复杂度证明。

### 8.3.4 正则化、稳定性与有限宽度

固定梯度特征还使训练目标成为可用凸学习分析的问题。范数路线控制函数空间，稳定性路线则比较更换样本后的算法输出。一次训练中核变化小只约束时间变化，尚未控制两份相邻样本产生的函数距离。

对 $g_{\boldsymbol{v}}(\boldsymbol{x}) = f_0(\boldsymbol{x}) + \langle \boldsymbol{v}, \boldsymbol{\varphi}_0(\boldsymbol{x})\rangle$ 加入二次惩罚，就可沿第 7.4节比较相邻样本的最优解。这里固定与样本独立的初始化，并要求 $\|\boldsymbol{\varphi}_0(\boldsymbol{x})\|_2 \le \kappa$。

**定理 8.10　正则化固定特征模型的稳定性**　设 $(X, \mathcal{X})$ 为可测输入空间，$(Y, \mathcal{Y})$ 为可测标签空间，$\mathcal{P}$ 为 $X \times Y$ 上的概率分布，且 $S = ((\boldsymbol{x}_1, y_1), \dots, (\boldsymbol{x}_n, y_n)) \sim \mathcal{P}^n$。在抽样前固定可测函数 $f_0 : X \to \mathbb{R}$ 和 $\boldsymbol{\varphi}_0 : X \to \mathbb{R}^p$，其中 $\|\boldsymbol{\varphi}_0(\boldsymbol{x})\|_2 \le \kappa$ 对所有 $\boldsymbol{x} \in X$ 成立，并令 $g_{\boldsymbol{v}}(\boldsymbol{x}) = f_0(\boldsymbol{x}) + \langle \boldsymbol{v}, \boldsymbol{\varphi}_0(\boldsymbol{x})\rangle$。设损失 $\ell : \mathbb{R} \times Y \to \mathbb{R}$ 可测，关于第一个变量凸且为 $G$-Lipschitz，并满足 $\mathbb{E}_{(\boldsymbol{x},y)\sim\mathcal{P}}|\ell(f_0(\boldsymbol{x}), y)| < \infty$。定义

$$R(g_{\boldsymbol{v}}) = \mathbb{E}_{(\boldsymbol{x},y)\sim\mathcal{P}}\ell(g_{\boldsymbol{v}}(\boldsymbol{x}), y), \qquad \hat{R}_S(g_{\boldsymbol{v}}) = \frac{1}{n}\sum_{i=1}^{n}\ell(g_{\boldsymbol{v}}(\boldsymbol{x}_i), y_i).$$

对 $G, \kappa, \lambda > 0$，令

$$\widehat{\boldsymbol{v}}_S = \arg\min_{\boldsymbol{v}}\left\{\frac{1}{n}\sum_{i=1}^{n}\ell(g_{\boldsymbol{v}}(\boldsymbol{x}_i), y_i) + \frac{\lambda}{2}\|\boldsymbol{v}\|_2^2\right\}, \qquad \lambda > 0.$$

则算法的均匀稳定性至多为 $2G^2\kappa^2/(\lambda n)$，且对任意固定 $\boldsymbol{v} \in \mathbb{R}^p$，

$$\mathbb{E}_S R(g_{\widehat{\boldsymbol{v}}_S}) - R(g_{\boldsymbol{v}}) \le \frac{2G^2\kappa^2}{\lambda n} + \frac{\lambda}{2}\|\boldsymbol{v}\|_2^2.$$

**证明**　单个样本损失关于 $\boldsymbol{v}$ 为 $G\kappa$-Lipschitz，经验目标为 $\lambda$-强凸。定理 7.34给出替换一个样本后的参数距离上界 $2G\kappa/(\lambda n)$，再乘损失的 Lipschitz 常数即得均匀稳定性及期望泛化差上界。正则化最优性还保证

$$\hat{R}_S(g_{\widehat{\boldsymbol{v}}_S}) \le \hat{R}_S(g_{\boldsymbol{v}}) + \frac{\lambda}{2}\|\boldsymbol{v}\|_2^2.$$

对样本取期望，并使用固定 $\boldsymbol{v}$ 的经验风险期望等于期望风险，得到结论。 ■

指定比较半径 $B > 0$，取 $\lambda = 2G\kappa/(B\sqrt{n})$，得到

$$\mathbb{E}_S R(g_{\widehat{\boldsymbol{v}}_S}) - \inf_{\|\boldsymbol{v}\|_2 \le B} R(g_{\boldsymbol{v}}) \le \frac{2G\kappa B}{\sqrt{n}}. \tag{8.12}$$

这个选择平衡稳定性代价与正则化比较代价：$\lambda$ 增大时前者下降、后者上升。小特征值方向的放大由此受到限制。当前结论要求凸 Lipschitz 损失，前面的 Rademacher 结论要求有界 Lipschitz 损失，二者的概率保证也不同。

真实有限宽网络还需从固定特征模型转回实际输出。记两者为 $f_S, g_S$，若以概率至少 $1-\delta_{\text{app}}$ 对样本、初始化及算法随机性满足

$$\mathbb{E}_{\boldsymbol{x}\sim\mathcal{P}_X}|f_S(\boldsymbol{x})-g_S(\boldsymbol{x})|\le\tau_n,$$

则 $G$-Lipschitz 损失把期望风险差控制在 $G\tau_n$。对 $\mathcal{P}_X$ 几乎处处一致的 $\tau_n$ 界同样足够；近似成功事件需与复杂度事件一起计失败概率。只有训练输入上的核矩阵接近，尚未证明新输入上的这个误差。因此完整风险保证同时依赖复杂度、经验拟合与近似控制。特征明显改变时，需要转向整个更新过程。

## 8.4 基于参数梯度更新的可学习性

固定初始梯度适用于特征变化受控的训练。更一般的训练会改变这些特征，参数化和优化器也参与选择解。我们于是把分析对象从初始响应改为从初始化到结束的整条轨迹。

固定步长梯度下降累加为

$$\theta^{(t)}=\theta^{(0)}-\eta\sum_{s=0}^{t-1}\nabla_\theta\hat{R}_S(\theta^{(s)}).$$

各项梯度在此前更新决定的位置计算，因此彼此依赖。两个参数即使当前经验风险相等，参数化、初始化和过去路径不同，也可能产生不同后续方向。**梯度动力学**（gradient dynamics）研究这些连续更新怎样决定最终函数。

由初始化、损失、参数化和更新共同产生的选解倾向，称为**隐式偏差**（implicit bias）。这里偏差描述算法偏好，不是风险分解中的近似误差，也不是某次更新本身。线性平方损失可选最小范数插值解，线性逻辑损失可选最大间隔方向，矩阵分解则可改变奇异值增长；每种结论都须保留相应条件。

选解性质还不是风险保证。我们可以先证明所选解具有受控范数、间隔或谱结构，再应用复杂度或直接风险分析；也可以比较相邻样本的最终输出，直接通过稳定性控制泛化差。

### 8.4.1 参数更新、隐式偏差与泛化路径

下面分别用三个可解场景观察更新选择：平方损失线性回归收敛到有限的最小范数解，可分逻辑分类的参数发散而方向趋于最大间隔，矩阵分解改变端到端谱演化。它们是并列机制，不是连续步骤，也不会统一导向核范数。每个场景都需要自己的数据与泛化条件。

这些分析共用式 (8.2)。更新若选出受控几何结构，就用相应风险界控制泛化差；若映射 $S \mapsto A(S)$ 稳定，则直接使用稳定性界。算法随机化时，平均还要包括内部随机数。接下来的三个场景展开前一路径，最后再讨论后一路径。

### 8.4.2 最小范数与线性回归泛化

只有训练观测 $\boldsymbol{x} = (1,1)^\top, y = 1$ 时，插值要求 $w_1 + w_2 = 1$。$(1,0)^\top$、$(0,1)^\top$ 和 $(1/2,1/2)^\top$ 都可拟合，却在新输入 $(1,0)^\top$ 上分别输出 1、0 与 $1/2$。零初始化下，两梯度分量始终相同，轨迹保持 $w_1 = w_2$，只能趋于中点。其他解为 $(1/2 + a, 1/2 - a)^\top$，范数平方为 $1/2 + 2a^2$，所以中点正是最小范数者。

图 8.6在参数平面画出这条插值直线。零初始化轨迹沿 $w_1 = w_2$ 抵达离原点最近的点；直线其余点也满足训练约束，却对相同新输入给出不同预测。图只固定了选解，还没有提供新输入标签。

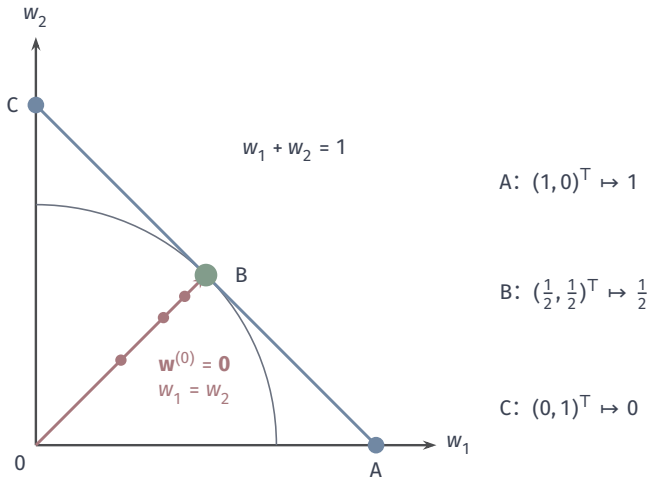


图 8.6　一个训练观测对应多个插值参数。直线上的 A、B、C 都使输入 $(1,1)^\top$ 的预测为 1，右侧列出它们对同一新输入 $\boldsymbol{x}_{\text{new}} = (1,0)^\top$ 的预测。对半平方损失从零初始化，图中以步长 1/4 画出前三次更新，轨迹趋向 B；细弧表示经过 B 的欧氏范数等值线，说明 B 是插值直线上距离原点最近的点。这个教学例子解释选解规则，不给出新输入的真实标签或泛化保证。

**定理 8.11　梯度下降的最小范数选择**　设 $n, d \geq 1$ 且 $d > n$，$\boldsymbol{X} \in \mathbb{R}^{n \times d}$ 满行秩，$\boldsymbol{y} \in \mathbb{R}^n$。对 $\hat{R}_S(\boldsymbol{w}) = \|\boldsymbol{X}\boldsymbol{w} - \boldsymbol{y}\|_2^2/(2n)$，令

$$\boldsymbol{w}^{(t+1)} = \boldsymbol{w}^{(t)} - \eta \nabla \hat{R}_S(\boldsymbol{w}^{(t)}), \qquad \boldsymbol{w}^{(0)} = 0.$$

若步长 $0 < \eta < 2n/\|\boldsymbol{X}\|_2^2$，则

$$\boldsymbol{w}^{(t)} \longrightarrow \hat{\boldsymbol{w}} = \boldsymbol{X}^{\top}(\boldsymbol{X}\boldsymbol{X}^{\top})^{-1}\boldsymbol{y} = \operatorname*{arg\,min}_{\boldsymbol{X}\boldsymbol{w}=\boldsymbol{y}} \|\boldsymbol{w}\|_2. \tag{8.13}$$

**证明** 每次更新的增量为 $-\eta\boldsymbol{X}^{\top}(\boldsymbol{X}\boldsymbol{w}^{(t)} - \boldsymbol{y})/n$，故所有迭代都在 $\operatorname{range}(\boldsymbol{X}^{\top})$ 内。残差满足

$$\boldsymbol{e}^{(t+1)} = \left(\boldsymbol{I} - \frac{\eta}{n}\boldsymbol{X}\boldsymbol{X}^{\top}\right)\boldsymbol{e}^{(t)}.$$

满行秩使 $\boldsymbol{X}\boldsymbol{X}^{\top}$ 正定；步长条件使括号内全部特征值的绝对值小于 1，所以残差趋于零。在上述行空间内，插值解唯一，正是式 (8.13) 中的 $\hat{\boldsymbol{w}}$。任意其他插值解均可写成

$$\boldsymbol{w} = \hat{\boldsymbol{w}} + \boldsymbol{v}, \qquad \boldsymbol{v} \in \operatorname{null}(\boldsymbol{X}). \tag{8.14}$$

行空间与零空间正交，故 $\|\boldsymbol{w}\|_2^2 = \|\hat{\boldsymbol{w}}\|_2^2 + \|\boldsymbol{v}\|_2^2$。这证明了最小范数性质。 ■

零初始化排除了零空间分量。若初值已有此分量，梯度不会消除它，极限就未必最小范数。深层参数化还改变同一函数的参数表示及范数，因而不能把线性结论直接推广到全部网络。

确定最小范数解后，我们还要计算它在新输入上的误差。将参数代入线性回归风险，可以分辨哪些误差来自未观察方向、哪些来自噪声，并说明为何选解规则没有脱离分布的统一样本量公式。

固定标签模型 $y = \boldsymbol{x}^{\top}\boldsymbol{w}_\star + \xi$，噪声与输入独立，均值零、方差 $\sigma^2$，并记 $\boldsymbol{\Sigma} = \mathbb{E}[\boldsymbol{x}\boldsymbol{x}^{\top}]$。风险采用完整平方损失 $(\boldsymbol{x}^{\top}\boldsymbol{w} - y)^2$；前面优化的半平方损失只差常数，不改变最小范数极限。展开新观测误差，独立零均值噪声消去交叉项，得到

$$R(\boldsymbol{w}) - R(\boldsymbol{w}_\star) = \|\boldsymbol{w} - \boldsymbol{w}_\star\|_{\boldsymbol{\Sigma}}^2, \qquad \|\boldsymbol{v}\|_{\boldsymbol{\Sigma}}^2 = \boldsymbol{v}^{\top}\boldsymbol{\Sigma}\boldsymbol{v}.$$

这个加权距离按输入变化评价参数误差，因此仅看欧氏距离不能确定预测风险。

**定理 8.12 基于最小范数的回归期望风险** 设 $\boldsymbol{x} \in \mathbb{R}^d$ 为满足 $\mathbb{E}\|\boldsymbol{x}\|_2^2 < \infty$ 的测试输入，$\boldsymbol{\Sigma} = \mathbb{E}[\boldsymbol{x}\boldsymbol{x}^{\top}]$。给定 $\boldsymbol{w}_\star \in \mathbb{R}^d$，令测试

标签 $y = \boldsymbol{x}^\top \boldsymbol{w}_\star + \xi$，其中 $\mathbb{E}[\xi \mid \boldsymbol{x}] = 0$ 且 $\mathbb{E}[\xi^2] < \infty$，并用完整平方损失定义

$$R(\boldsymbol{w}) = \mathbb{E}[(\boldsymbol{x}^\top \boldsymbol{w} - y)^2].$$

固定满行秩设计矩阵 $\boldsymbol{X} \in \mathbb{R}^{n \times d}$，其中 $n < d$，训练标签为 $\boldsymbol{y} = \boldsymbol{X}\boldsymbol{w}_\star + \boldsymbol{\xi}$，其中 $\mathbb{E}[\boldsymbol{\xi} \mid \boldsymbol{X}] = 0$、$\mathbb{E}[\boldsymbol{\xi}\boldsymbol{\xi}^\top \mid \boldsymbol{X}] = \sigma^2 \boldsymbol{I}_n$ 且 $\sigma^2 \geq 0$。令 $\hat{\boldsymbol{w}} = \boldsymbol{X}^\top (\boldsymbol{X}\boldsymbol{X}^\top)^{-1} \boldsymbol{y}$，$\boldsymbol{P}_X = \boldsymbol{X}^\top (\boldsymbol{X}\boldsymbol{X}^\top)^{-1} \boldsymbol{X}$。则

$$\begin{aligned} &\mathbb{E}_{\boldsymbol{\xi} \mid \boldsymbol{X}}[R(\hat{\boldsymbol{w}}) - R(\boldsymbol{w}_\star)] \\ &\quad = \|(\boldsymbol{I} - \boldsymbol{P}_X)\boldsymbol{w}_\star\|_{\boldsymbol{\Sigma}}^2 + \sigma^2 \operatorname{tr}\left[\boldsymbol{\Sigma}\boldsymbol{X}^\top (\boldsymbol{X}\boldsymbol{X}^\top)^{-2} \boldsymbol{X}\right]. \end{aligned} \tag{8.15}$$

**证明**　把训练标签代入最小范数解，有

$$\hat{\boldsymbol{w}} - \boldsymbol{w}_\star = -(\boldsymbol{I} - \boldsymbol{P}_X)\boldsymbol{w}_\star + \boldsymbol{X}^\top (\boldsymbol{X}\boldsymbol{X}^\top)^{-1} \boldsymbol{\xi}.$$

在 $\boldsymbol{\Sigma}$ 半范数下展开平方。条件噪声均值为零，使交叉项的期望为零；利用 $\mathbb{E}[\boldsymbol{\xi}\boldsymbol{\xi}^\top \mid \boldsymbol{X}] = \sigma^2 \boldsymbol{I}$ 计算最后一项，就得到迹表达式。 ■

若设计矩阵也随机且式 (8.15)右侧可积，再对 $\boldsymbol{X}$ 平均即可包括全部训练随机性。第一项对应样本未确定的目标方向，零初始化不会补出零空间中的目标；第二项对应拟合训练噪声，矩阵逆可能放大某些噪声方向。最小范数选择本身没有排除两者。零一风险的范数界也不能替代这里平方损失下的分布计算。

协方差谱改变两类误差的权重。Bartlett 等的良性过拟合分析说明，特定谱条件下，最小范数插值可以拟合噪声并保持小超额风险[9]。因此样本量分析必须同时说明算法选解与分布评价，不能只另换一个参数计数公式。

一个精确例子取无噪声和各向同性输入：$\boldsymbol{x}_i \sim \mathcal{N}(0, \boldsymbol{I}_d)$，$\sigma = 0$，故 $\boldsymbol{\Sigma} = \boldsymbol{I}_d$。随机 $n$ 维样本子空间具有旋转对称性，期望投影只能是单位矩阵的倍数；由 $\operatorname{tr}(\boldsymbol{P}_X) = n$ 可知 $\mathbb{E}\boldsymbol{P}_X = (n/d)\boldsymbol{I}_d$。于是

$$\mathbb{E}_S[R(\hat{\boldsymbol{w}}) - R(\boldsymbol{w}_\star)] = \left(1 - \frac{n}{d}\right) \|\boldsymbol{w}_\star\|_2^2, \qquad n < d. \tag{8.16}$$

$\|\boldsymbol{w}_\star\|_2 = 1, d = 100, n = 10$ 时，经验风险为零而平均超额风险为 0.9。由精确式，使风险至多 $\varepsilon < 1$ 需要 $n \geq d(1 - \varepsilon)$。这个例子保留了维度影响，显示最小范数不会自动消除未观察方向的误差。

### 8.4.3 最大间隔与线性分类泛化

逻辑分类与平方回归的参数极限不同。对线性可分数据，沿正确方向放大参数会持续降低 $\log(1+e^{-y\boldsymbol{w}^\top \boldsymbol{x}})$。经验风险下确界为零，却通常没有有限参数达到它。因此应追踪归一化方向，而不是要求参数向量收敛。

取 $y_i \in \{-1,1\}$，可分要求存在 $\boldsymbol{w}$ 使所有 $y_i \boldsymbol{w}^\top \boldsymbol{x}_i > 0$。单位方向 $\boldsymbol{u}$ 满足 $\|\boldsymbol{u}\|_2 = 1$，其最小经验间隔为 $\min_i y_i \boldsymbol{u}^\top \boldsymbol{x}_i$。将未归一化间隔固定为至少 1 后最小化范数，等价于最大化单位方向的这个最小值，得到硬间隔支持向量机的几何目标。

**定理 8.13　逻辑回归梯度下降的最大间隔方向**　设 $n, d \ge 1$，$\boldsymbol{x}_i \in \mathbb{R}^d$、$y_i \in \{-1,+1\}$，且存在 $\boldsymbol{w} \in \mathbb{R}^d$ 使 $y_i \boldsymbol{w}^\top \boldsymbol{x}_i > 0$ 对所有 $1 \le i \le n$ 成立。令 $\boldsymbol{X} \in \mathbb{R}^{n\times d}$ 以 $\boldsymbol{x}_i^\top$ 为第 $i$ 行，并定义

$$\hat{R}_S(\boldsymbol{w}) = \frac{1}{n}\sum_{i=1}^{n} \log\left(1 + e^{-y_i \boldsymbol{w}^\top \boldsymbol{x}_i}\right)$$

以及迭代

$$\boldsymbol{w}^{(t+1)} = \boldsymbol{w}^{(t)} - \eta \nabla \hat{R}_S(\boldsymbol{w}^{(t)}).$$

从任意 $\boldsymbol{w}^{(0)} \in \mathbb{R}^d$ 出发，取 $0 < \eta < n/\|\boldsymbol{X}\|_2^2$。则 $\|\boldsymbol{w}^{(t)}\|_2 \to \infty$，且

$$\frac{\boldsymbol{w}^{(t)}}{\|\boldsymbol{w}^{(t)}\|_2} \longrightarrow \frac{\widehat{\boldsymbol{w}}_{\mathrm{svm}}}{\|\widehat{\boldsymbol{w}}_{\mathrm{svm}}\|_2},$$

其中

$$\widehat{\boldsymbol{w}}_{\mathrm{svm}} = \arg\min_{\boldsymbol{w}} \tfrac{1}{2}\|\boldsymbol{w}\|_2^2 \quad \text{满足} \quad y_i \boldsymbol{w}^\top \boldsymbol{x}_i \ge 1 \quad (1 \le i \le n).$$

以下证明采用 Soudry 等对可分逻辑回归证明的渐近展开[10]。

**证明（使用外部渐近结果）**　在上述保守步长条件下，$\boldsymbol{w}^{(t)} = \widehat{\boldsymbol{w}}_{\mathrm{svm}} \log t + \boldsymbol{\rho}^{(t)}$，其中 $\|\boldsymbol{\rho}^{(t)}\|_2 = O(\log\log t)$。由于 $\log\log t / \log t \to 0$，除以 $\log t$ 后取极限得到 $\widehat{\boldsymbol{w}}_{\mathrm{svm}}$。该向量非零，故参数范数发散，并且归一化方向收敛到所述方向。这里的渐近展开是所引用的外部结果，本段只证明由该展开到方向收敛的推论。 ■

我们从梯度权重观察这一方向选择：

$$-\nabla \hat{R}_S(\boldsymbol{w}) = \frac{1}{n}\sum_{i=1}^{n} \frac{y_i \boldsymbol{x}_i}{1 + e^{y_i \boldsymbol{w}^\top \boldsymbol{x}_i}}.$$

[10] D. Soudry, E. Hoffer, M. S. Nacson, S. Gunasekar, N. Srebro, *The Implicit Bias of Gradient Descent on Separable Data* In Journal of Machine Learning Research, 2018, vol. 19, no. 70, pp. 1–57

大间隔样本的更新权重衰减较快，靠近边界的样本则继续影响方向。分类错误已为零时，逻辑损失仍推动方向变化。这个机制解释不替代方向极限的渐近证明。

最大间隔方向可以通过前面的复杂度理论转为期望风险保证。

**定理 8.14　基于最大间隔的分类期望风险**　设 $X \subseteq \mathbb{R}^d$ 取 Borel $\sigma$ 代数，$Y = \{-1, +1\}$，$\mathcal{P}$ 为 $X \times Y$ 上的概率分布。令

$$S = ((\boldsymbol{x}_1, y_1), \dots, (\boldsymbol{x}_n, y_n)) \sim \mathcal{P}^n.$$

假设 $\|\boldsymbol{x}\|_2 \le r$ 在 $\mathcal{P}$ 下几乎处处成立，其中 $n \ge 1$、$r > 0$。事先固定 $\gamma > 0$ 和 $\delta \in (0, 1)$。则以概率至少 $1 - \delta$，所有满足 $\|\boldsymbol{u}\|_2 = 1$ 的方向同时满足

$$\mathbb{P}_{(\boldsymbol{x},y)\sim\mathcal{P}}\{y\boldsymbol{u}^\top \boldsymbol{x} \le 0\} \le \frac{1}{n}\sum_{i=1}^{n} \mathbb{I}\{y_i \boldsymbol{u}^\top \boldsymbol{x}_i \le \gamma\} + \frac{2r}{\gamma\sqrt{n}} + 3\sqrt{\frac{\log(2/\delta)}{2n}}. \tag{8.17}$$

左侧把零分数也计为错误，因而上界任意固定平局规则下的零一损失期望风险。

**证明**　单位范数线性函数类的经验 Rademacher 复杂度至多为 $r/\sqrt{n}$。取在负间隔处为 1、从 0 到 $\gamma$ 线性下降、在不小于 $\gamma$ 处为 0 的间隔损失。它以 $1/\gamma$ 为 Lipschitz 常数，上界控制零一损失，而它在训练样本上的取值又不超过 $\mathbb{I}\{y_i \boldsymbol{u}^\top \boldsymbol{x}_i \le \gamma\}$。对该损失应用 Rademacher 复杂度的 Lipschitz 收缩和统一期望风险界，即得结论。 ■

最大经验方向间隔若大于预定 $\gamma$，定理 8.13使充分训练后的方向达到这一阈值，式 (8.17)的经验项便为零。余项不超过 $\varepsilon$ 的充分样本量为 $O((r^2/\gamma^2 + \log(1/\delta))/\varepsilon^2)$ 量级。

真正进入风险的是归一化间隔。统一放大参数会同时放大原始间隔和范数，不改变比值；方向变化才可能改善它。样本可分也不保证随 $n$ 增长仍有固定正间隔，记忆噪声得到的小间隔可能使界失效。标签噪声、优化器或深层参数化改变时，都要重新证明选解性质。

### 8.4.4 谱偏好与矩阵预测的泛化

深层线性网络虽没有激活，参数目标仍可非凸。$\boldsymbol{W} = \boldsymbol{W}_L \cdots \boldsymbol{W}_1$ 给出线性输出 $\boldsymbol{W}\boldsymbol{x}$，不同分解表示同一映射，但对各因子的梯度包含其余因子，因而训练可以偏向不同端到端映射。

先用二层分解 $\boldsymbol{W} = \boldsymbol{U}\boldsymbol{V}^\top$ 计算这项区别。记经验目标 $\mathcal{L}(\boldsymbol{W})$ 及梯度 $\boldsymbol{G} = \nabla_{\boldsymbol{W}}\mathcal{L}$，链式法则给出

$$\dot{\boldsymbol{U}} = -\boldsymbol{G}\boldsymbol{V}, \qquad \dot{\boldsymbol{V}} = -\boldsymbol{G}^\top\boldsymbol{U}.$$

从而

$$\dot{\boldsymbol{W}} = -\boldsymbol{G}\boldsymbol{V}\boldsymbol{V}^\top - \boldsymbol{U}\boldsymbol{U}^\top\boldsymbol{G}. \tag{8.18}$$

直接训练 $\boldsymbol{W}$ 只用 $-\boldsymbol{G}$，分解则让梯度两侧乘上变化的矩阵。这些因子调节各方向的有效速度，即使没有显式范数惩罚，也会在轨迹中累积。

奇异值记录矩阵在各输入—输出方向的强度。少数非零奇异值意味着低秩，少数较大奇异值则允许低秩近似。对于多输出或矩阵观测，低秩表示若干预测方向共享较少线性结构。标量输出的端到端矩阵只有一行，不能用这项低秩解释概括其全部泛化行为。

为了精确求解多层谱演化,我们增加平衡初始化:相邻层满足 $\boldsymbol{W}_{j+1}^\top\boldsymbol{W}_{j+1} = \boldsymbol{W}_j\boldsymbol{W}_j^\top$。这使相邻因子的内积结构匹配，为下面的动力学提供可处理条件，并非任意初始化都具备的性质。

**定理 8.15　平衡深层线性网络的梯度流**　设 $L, q \geq 1$，$\boldsymbol{W}_j(t) \in \mathbb{R}^{q\times q}$，$\mathcal{L} : \mathbb{R}^{q\times q} \to \mathbb{R}$ 连续可微。记 $\boldsymbol{W} = \boldsymbol{W}_L \cdots \boldsymbol{W}_1$、$\boldsymbol{G} = \nabla\mathcal{L}(\boldsymbol{W})$，并令各因子满足

$$\dot{\boldsymbol{W}}_j = -(\boldsymbol{W}_L \cdots \boldsymbol{W}_{j+1})^\top \boldsymbol{G} (\boldsymbol{W}_{j-1} \cdots \boldsymbol{W}_1)^\top, \qquad 1 \leq j \leq L,$$

其中空乘积为 $\boldsymbol{I}_q$。假设初始化满足

$$\boldsymbol{W}_{j+1}(0)^\top\boldsymbol{W}_{j+1}(0) = \boldsymbol{W}_j(0)\boldsymbol{W}_j(0)^\top, \qquad 1 \leq j < L.$$

在该微分方程的解存在且各层满秩的时间区间内，平衡关系保持，且

$$\dot{\boldsymbol{W}} = -\sum_{j=1}^{L} (\boldsymbol{W}\boldsymbol{W}^\top)^{(L-j)/L} \boldsymbol{G} (\boldsymbol{W}^\top\boldsymbol{W})^{(j-1)/L}. \tag{8.19}$$

在某个正奇异值 $\sigma_k$ 为单重且可微的时刻，若其左右奇异向量为 $\boldsymbol{u}_k, \boldsymbol{v}_k$，则

$$\dot{\sigma}_k = -L\sigma_k^{2-2/L}\boldsymbol{u}_k^\top\boldsymbol{G}\boldsymbol{v}_k. \tag{8.20}$$

**证明**　写 $\boldsymbol{A}_j = \boldsymbol{W}_L \cdots \boldsymbol{W}_{j+1}$、$\boldsymbol{B}_j = \boldsymbol{W}_{j-1} \cdots \boldsymbol{W}_1$，空乘积取单位矩阵。链式法则给出 $\dot{\boldsymbol{W}}_j = -\boldsymbol{A}_j^{\top} \boldsymbol{G} \boldsymbol{B}_j^{\top}$，故

$$\dot{\boldsymbol{W}} = -\sum_j \boldsymbol{A}_j \boldsymbol{A}_j^{\top} \boldsymbol{G} \boldsymbol{B}_j^{\top} \boldsymbol{B}_j .$$

将同一导数代入相邻层的 Gram 矩阵，可核对 $\frac{\mathrm{d}}{\mathrm{d}t}(\boldsymbol{W}_{j+1}^{\top}\boldsymbol{W}_{j+1} - \boldsymbol{W}_j \boldsymbol{W}_j^{\top}) = 0$。平衡关系因而始终成立，并允许将各层写为相互匹配的奇异值分解 $\boldsymbol{W}_j = \boldsymbol{U}_j \boldsymbol{D} \boldsymbol{U}_{j-1}^{\top}$。于是 $\boldsymbol{W} = \boldsymbol{U}_L \boldsymbol{D}^L \boldsymbol{U}_0^{\top}$，而 $\boldsymbol{A}_j \boldsymbol{A}_j^{\top} = (\boldsymbol{W}\boldsymbol{W}^{\top})^{(L-j)/L}$、$\boldsymbol{B}_j^{\top}\boldsymbol{B}_j = (\boldsymbol{W}^{\top}\boldsymbol{W})^{(j-1)/L}$。代回乘积导数得到第一式。再用单重奇异值的微分关系 $\dot{\sigma}_k = \boldsymbol{u}_k^{\top} \dot{\boldsymbol{W}} \boldsymbol{v}_k$，每个求和项均贡献 $-\sigma_k^{2-2/L} \boldsymbol{u}_k^{\top} \boldsymbol{G} \boldsymbol{v}_k$，得到第二式。 ■

式 (8.20)中，其他梯度投影相近时，小奇异值方向更新较慢，大方向较快，因此可以解释少数方向先增长。但投影的符号和大小也随训练变化，不能由此保证任意数据上取得最低秩。Arora 等分析了这类深层分解谱偏好；离散应用还需控制步长与平衡误差[11]。

[11] S. Arora, N. Cohen, W. Hu, Y. Luo, *Implicit Regularization in Deep Matrix Factorization* In Advances in Neural Information Processing Systems, 2019

要进入复杂度界，我们还需矩阵的总尺度。**核范数**（nuclear norm）$\|\boldsymbol{W}\|_*$ 是奇异值之和，这里的“核”不同于 NTK 核函数。秩至多 $q$ 且 $\|\boldsymbol{W}\|_F \le F$ 时，Cauchy–Schwarz 给出 $\|\boldsymbol{W}\|_* \le \sqrt{q} F$。低秩只有连同受控尺度，才提供小核范数。

因子参数的大小与核范数之间存在一个精确的静态关系。

**引理 8.16　二层分解的范数关系**　设 $\boldsymbol{W} \in \mathbb{R}^{d_1 \times d_2}$，并取 $k \ge \operatorname{rank}(\boldsymbol{W})$。当 $\boldsymbol{U} \in \mathbb{R}^{d_1 \times k}$、$\boldsymbol{V} \in \mathbb{R}^{d_2 \times k}$ 时，

$$\|\boldsymbol{W}\|_* = \min_{\boldsymbol{U}\boldsymbol{V}^{\top} = \boldsymbol{W}} \frac{1}{2}\left(\|\boldsymbol{U}\|_F^2 + \|\boldsymbol{V}\|_F^2\right).$$

**证明**　核范数与谱范数的对偶关系以及 Cauchy–Schwarz 不等式给出 $\|\boldsymbol{U}\boldsymbol{V}^{\top}\|_* \le \|\boldsymbol{U}\|_F \|\boldsymbol{V}\|_F$，再用 $ab \le (a^2 + b^2)/2$ 得到下界。若 $\boldsymbol{W} = \boldsymbol{P}\boldsymbol{\Sigma}\boldsymbol{Q}^{\top}$ 是紧奇异值分解，取 $\boldsymbol{U} = \boldsymbol{P}\boldsymbol{\Sigma}^{1/2}$、$\boldsymbol{V} = \boldsymbol{Q}\boldsymbol{\Sigma}^{1/2}$，两因子的范数平方都等于 $\operatorname{tr}\boldsymbol{\Sigma}$，从而达到等号。当 $k > \operatorname{rank}(\boldsymbol{W})$ 时，在两因子后补零列以满足指定列数。 ■

引理联系的是显式因子范数最小化与端到端核范数，尚未说明单纯经验损失梯度流会最小化它。Gunasekar 等的有关结论还要求观测矩阵两两可交换、初始化趋零及插值极限存在等条件[12]。链式法则给不出这些额外性质。

[12] S. Gunasekar, B. E. Woodworth, S. Bhojanapalli, B. Neyshabur, N. Srebro, *Implicit Regularization in Matrix Factorization* In Advances in Neural Information Processing Systems, 2017

还有选解不能由范数最小化概括的情形。Razin 与 Cohen 构造矩阵分解问题，使平方经验风险趋零而所有矩阵范数发散[13]。所以谱的低秩趋势、核范数界和显式正则化须分别证明，不能统一称作隐式核范数惩罚。

若训练确实得到受控核范数，我们再固定它服务的预测问题：输入矩阵 $\boldsymbol{A}$，输出 $h_{\boldsymbol{W}}(\boldsymbol{A}) = \langle \boldsymbol{W}, \boldsymbol{A} \rangle_F$，内积为对应元素乘积之和。$\boldsymbol{A}$ 可以选择单个待预测元素，也可以表示多个元素的线性观测。这个观测级风险是后面复杂度界的评价对象。

将 $\boldsymbol{W}$ 写为奇异值与秩一方向之和，每个单位方向满足 $|\boldsymbol{u}^\top \boldsymbol{A} \boldsymbol{v}| \le \|\boldsymbol{A}\|_2$，因此

$$|\langle \boldsymbol{W}, \boldsymbol{A} \rangle_F| \le \|\boldsymbol{W}\|_* \|\boldsymbol{A}\|_2.$$

沿 $\boldsymbol{A}$ 最大奇异方向分配全部核范数可取等号。这一对偶关系在模型侧限制总奇异值，在输入侧控制最大方向强度，将矩阵约束接到预测幅度。

**定理 8.17　基于谱结构的矩阵预测期望风险**　设 $n, d_1, d_2 \ge 1$，矩阵输入空间为 $\mathbb{R}^{d_1 \times d_2}$，$(Y, \mathcal{Y})$ 为可测标签空间，$\mathcal{P}$ 为 $\mathbb{R}^{d_1 \times d_2} \times Y$ 上的概率分布，且 $S = ((\boldsymbol{A}_1, y_1), \dots, (\boldsymbol{A}_n, y_n)) \sim \mathcal{P}^n$。假设 $\|\boldsymbol{A}\|_F \le r$ 在 $\mathcal{P}$ 下几乎处处成立。对 $\boldsymbol{W} \in \mathbb{R}^{d_1 \times d_2}$，令 $h_{\boldsymbol{W}}(\boldsymbol{A}) = \langle \boldsymbol{W}, \boldsymbol{A} \rangle_F$。损失 $\ell : \mathbb{R} \times Y \to [0, 1]$ 可测，且关于预测值为 $G$-Lipschitz；定义

$$R(h_{\boldsymbol{W}}) = \mathbb{E}_{(\boldsymbol{A}, y) \sim \mathcal{P}} \ell(h_{\boldsymbol{W}}(\boldsymbol{A}), y), \qquad \hat{R}_S(h_{\boldsymbol{W}}) = \frac{1}{n} \sum_{i=1}^{n} \ell(h_{\boldsymbol{W}}(\boldsymbol{A}_i), y_i).$$

固定 $B, r, G > 0$ 和 $\delta \in (0, 1)$，以概率至少 $1 - \delta$，所有 $\|\boldsymbol{W}\|_* \le B$ 同时满足

$$R(h_{\boldsymbol{W}}) \le \hat{R}_S(h_{\boldsymbol{W}}) + \frac{2GBr}{\sqrt{n}} + 3\sqrt{\frac{\log(2/\delta)}{2n}}.$$

特别地，若对某个矩阵分解训练算法另行证明其输出 $\boldsymbol{W}_S$ 满足 $\|\boldsymbol{W}_S\|_* \le B$，则 $\boldsymbol{W}_S$ 服从同一个期望风险界。若进一步规定 $q \ge 1$、$F > 0$、$\operatorname{rank}(\boldsymbol{W}) \le q$ 且 $\|\boldsymbol{W}\|_F \le F$，可将复杂度项中的 $B$ 取为 $\sqrt{q}F$。

**证明**　由核范数与谱范数的对偶关系，预测函数空间的经验 Rademacher 复杂度为

$$\frac{B}{n} \mathbb{E}_{\boldsymbol{\sigma}} \left\| \sum_{i=1}^{n} \sigma_i \boldsymbol{A}_i \right\|_2 \le \frac{B}{n} \sqrt{\sum_{i=1}^{n} \|\boldsymbol{A}_i\|_F^2} \le \frac{Br}{\sqrt{n}}.$$

[13] N. Razin, N. Cohen, *Implicit Regularization in Deep Learning May Not Be Explainable by Norms* In Advances in Neural Information Processing Systems, 2020

其中先用谱范数不超过 Frobenius 范数，再利用随机正负号使平方展开的交叉项期望为零。对损失应用 Lipschitz 收缩与经验 Rademacher 期望风险界，即得结论。低秩情形由 $\|\boldsymbol{W}\|_* \le \sqrt{q}\|\boldsymbol{W}\|_F$ 得到。 ■

在所列核范数条件下，使风险附加项至多 $\varepsilon$ 的充分样本量为 $O((G^2B^2r^2+\log(1/\delta))/\varepsilon^2)$。若秩为 $q$ 且尺度受控，可将相应量写为 $G^2qF^2r^2$。这说明低秩如何进入保证；$F, r$ 仍可能随矩阵规模增长，因此并未无条件消除维度影响。

这个风险评价观测分布中的预测，完整恢复未知矩阵还要覆盖、噪声和目标结构条件。我们先证明动力学在指定初始化及数据下选出某类矩阵，再控制其核范数或其他复杂度，最后计算风险。更新链式法则只完成几何解释，不能独立证明可学习性。

### 8.4.5 参数更新的稳定性与泛化

最小范数选择不等于样本稳定。固定 $\boldsymbol{X}$ 而把标签改为 $\boldsymbol{y}+\Delta\boldsymbol{y}$，由最小范数解及奇异值分解可得

$$\Delta\hat{\boldsymbol{w}} = \boldsymbol{X}^\top(\boldsymbol{X}\boldsymbol{X}^\top)^{-1}\Delta\boldsymbol{y}, \qquad \|\Delta\hat{\boldsymbol{w}}\|_2 \le \frac{\|\Delta\boldsymbol{y}\|_2}{\sigma_{\min}(\boldsymbol{X})}.$$

$\sigma_{\min}(\boldsymbol{X})$ 是最小非零奇异值，它小时，即使标签变化小，参数仍可能明显改变。完整样本替换还会改变 $\boldsymbol{X}$，所以这个固定设计例子仅帮助定位敏感方向。

要沿第 7.3节使用参数稳定性，必须实际证明上述变化小，并检查损失的 Lipschitz 转换。逻辑回归则可能参数范数发散而方向稳定，原参数距离未必适合当前评价。此时可以直接比较预测函数或损失。

若已证明平均参数稳定性 $\bar{\alpha}_n$，损失关于参数为 $L_\theta$-Lipschitz，经验优化误差至多 $\rho_n$，定理 7.22给出

$$\mathbb{E}_S R(A(S)) - \inf_{h\in\mathcal{H}} R(h) \le L_\theta\bar{\alpha}_n + \rho_n.$$

深层网络还可按定理 8.5逐层传播变化。隐式偏差帮助确定选解映射 $S \mapsto A(S)$，稳定性则把这一映射的样本敏感度转为风险。比较必须使用相邻训练样本，不能以一次训练中相邻迭代的距离代替。

初始化、优化器或参数化改变后，算法偏好的范数与间隔可能变化，但风险判断仍需同时核对经验拟合、预测性质和样本敏感度。例如，可分逻辑回归继续训练可增大归一化间隔，同时使参数范数发散，所以参数范数下降不能作为统一训练准则。

矩阵分解还存在表示冗余：不同因子可给出同一端到端矩阵。若任务只评价预测，应区分因子变化与矩阵变化，或直接比较相邻样本下的损失。

动力学确定算法选什么解，稳定性确定换一个样本时所选解改变多少。结合它们仍要检查分布与风险，双重下降区域同样如此：最小范数是否有益，取决于输入谱、噪声和目标，不由 $p > n$ 单独决定。

## 8.5 基于参数分布的可学习性

### 8.5.1 参数分布的两种语义

此前以参数点描述训练输出。宽网络还可以把大量参数组织为分布，以追踪神经元群体或训练结果附近的网络集合。采用这项描述前，必须先决定概率质量的基本单位，因为下面两种分布代表不同对象。

第一种单位是神经元：同一网络的神经元参数组成经验分布 $\rho$，对单元输出积分得到确定函数 $f_\rho$，平均场理论研究 $\rho$ 的演化。第二种单位是完整网络：后验 $Q$ 在完整参数向量上取值，每次抽取才得到一个完整预测器。前者表示一个网络，后者描述随机网络输出，不能因都用概率测度就混同。

图 8.7固定这两个基本单位。左侧以神经元为积分单位，得到一个确定预测器；右侧从完整参数向量的后验中抽取随机预测器。概率质量所对应的单位不同，不能把两种运算互相替代。

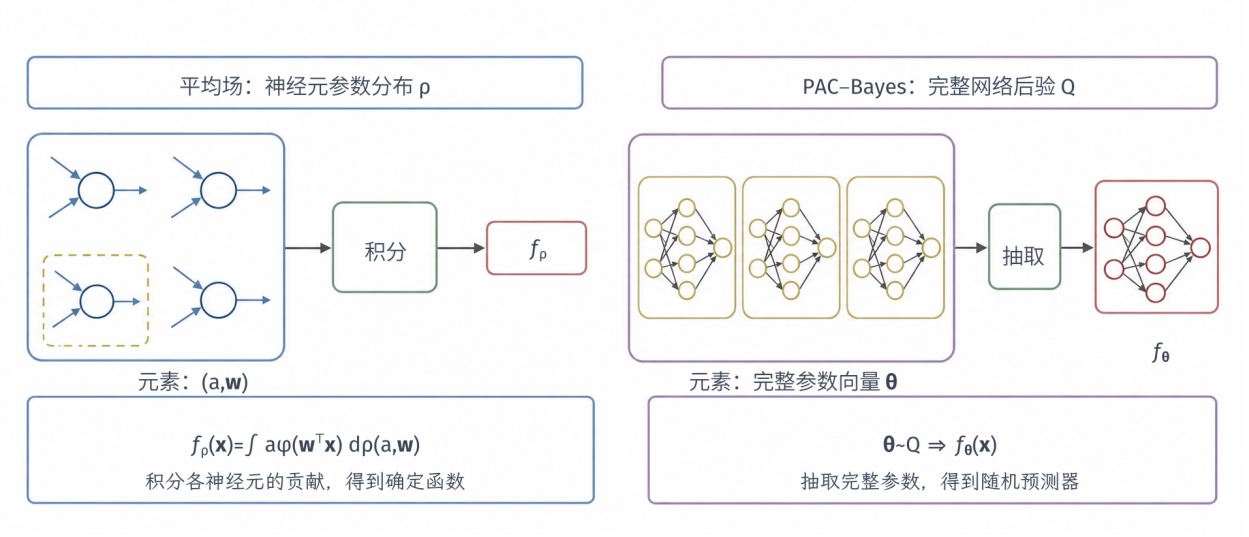


图 8.7　两种分布的基本元素不同。平均场侧对单个神经元的贡献 $a\phi(\boldsymbol{w}^\top\boldsymbol{x})$ 积分，由神经元参数分布 $\rho$ 得到确定性预测器 $f_\rho$；网络、参数集合与积分表示同一预测器的不同表述，不是对完整网络的输出再做集成。PAC–Bayes 侧的 $Q$ 以完整参数向量为元素，抽取 $\theta$ 后才得到完整预测器 $f_\theta$。

比较相邻样本产生的同类分布时，我们采用一阶 Wasserstein 距离。它在保持两边边缘分布的配对中，寻找最低的平均搬运距离；在完备可分度

量空间及有限一阶矩条件下，这给出有限的分布距离（可参考第一卷“概率分布”章的“质量位置的差异”一节）。当前参数空间为欧氏空间，分布均有有限一阶矩。$W_1(\rho_S, \rho_{S'})$ 在神经元空间中比较群体，$W_1(Q_S, Q_{S'})$ 在完整网络空间中比较随机输出，两者不是同一底层空间。

风险分析也随单位改变。神经元分布先经积分变为预测函数，再由复杂度或样本稳定性控制泛化；完整网络后验则可与独立先验比较，以相对熵给出随机预测风险界。下面分别推导，并说明 Wasserstein 距离、相对熵和互信息所比较的分布。

### 8.5.2 平均场表示与 Wasserstein 稳定性接口

特征随训练持续改变时，我们希望记录神经元整体怎样移动。平均场方法用参数空间中的质量分布替代逐个单元的记录，再研究质量演化。

取 $m$ 隐藏单元的两层网络，使用 $1/m$ 缩放：

$$f_m(\boldsymbol{x}) = \frac{1}{m}\sum_{j=1}^{m} a_j \phi(\boldsymbol{w}_j^{\top}\boldsymbol{x}).$$

给每个 $(a_j, \boldsymbol{w}_j)$ 赋质量 $1/m$，得到 $\rho_m = m^{-1}\sum_{j=1}^{m}\delta_{(a_j,\boldsymbol{w}_j)}$，其中 $\delta_{(a,\boldsymbol{w})}$ 是在 $(a, \boldsymbol{w})$ 处的点质量分布。求和便等于

$$f_{\rho_m}(\boldsymbol{x}) = \int a\phi(\boldsymbol{w}^{\top}\boldsymbol{x})\,\mathrm{d}\rho_m(a, \boldsymbol{w}). \tag{8.21}$$

例如两种参数各占一半时，输出为两种单元贡献的平均；按同样比例复制全部单元，积分不变。分布在此表示单个网络的组成。

**平均场理论**（mean-field theory）分析适当缩放下 $\rho_m$ 趋近连续分布 $\rho$ 时的训练。Mei 等给出两层网络的极限及有限宽近似[14,15]。训练中质量移动会改变 $\boldsymbol{w}$ 及其特征，因此区别于固定核。两种极限依赖缩放与训练条件，不能简单按宽网络和窄网络划分。

积分对 $\rho$ 线性，所以预测损失凸时，风险作为分布的函数也凸。但有限网络通过移动有限个质量点优化，参数化仍可非凸。分布凸性没有直接保证普通梯度下降全局收敛，也没有单独控制样本泛化。

我们进一步比较替换一项后得到的 $\rho_S, \rho_{S'}$。固定参数域 $\Theta \subseteq \mathbb{R}^q$ 和输入域 $\mathcal{X}$，要求 $\rho_S \in \mathcal{P}_1(\Theta)$，单元输出 $\psi_{\vartheta}(\boldsymbol{x})$ 对所有 $\boldsymbol{x} \in \mathcal{X}$ 一致地关于 $\vartheta \in \Theta$ 为 $L_\psi$-Lipschitz，预测损失为 $G$-Lipschitz。若相邻样本满足 $W_1(\rho_S, \rho_{S'}) \le a_n$，则

$$\left|\mathbb{E}_S\left[R(f_{\rho_S}) - \hat{R}_S(f_{\rho_S})\right]\right| \le G L_\psi a_n.$$

为看清转换，对任意耦合 $\pi \in \Pi(\rho_S, \rho_{S'})$ 有

$$|f_{\rho_S}(\boldsymbol{x}) - f_{\rho_{S'}}(\boldsymbol{x})| \le L_\psi \mathbb{E}_\pi \|\vartheta - \vartheta'\|_2.$$

[14] S. Mei, A. Montanari, P.-M. Nguyen, *A Mean Field View of the Landscape of Two-Layers Neural Networks* In arXiv preprint arXiv:1804.06561, 2018

[15] S. Mei, T. Misiakiewicz, A. Montanari, *Mean-field Theory of Two-layers Neural Networks: Dimension-free Bounds and Kernel Limit* In arXiv preprint arXiv:1902.06015, 2019

对耦合取下确界，再转换损失并应用第 7.3节的恒等式，即得泛化界。对 $\psi_{(a,\boldsymbol{w})}(\boldsymbol{x}) = a\phi(\boldsymbol{w}^{\top}\boldsymbol{x})$，输入、$a, \boldsymbol{w}$ 有界加上激活 Lipschitz 性可验证统一 $L_{\psi}$；也可用其他假设直接证明同一个界。推导需要的正是这一致界。

上述推导只给出稳定性接口，尚未从某个动力学证明 $a_n$。具体算法还需初始化耦合、训练时长、损失与势函数正则性，以及相邻样本的 Wasserstein 速率。要比较最优风险，再固定允许分布集合 $\mathcal{M}$，要求输出 $\rho_S \in \mathcal{M}$ 满足

$$\mathbb{E}_S\left[\hat{R}_S(f_{\rho_S}) - \inf_{\rho\in\mathcal{M}} \hat{R}_S(f_{\rho})\right] \le \xi_n.$$

固定 $\rho \in \mathcal{M}$ 有 $\mathbb{E}_S\hat{R}_S(f_{\rho}) = R(f_{\rho})$，从而 $\mathbb{E}_S \inf_{\rho\in\mathcal{M}} \hat{R}_S(f_{\rho}) \le \inf_{\rho\in\mathcal{M}} R(f_{\rho})$。与泛化差合并，得到

$$0 \le \mathbb{E}_S R(f_{\rho_S}) - \inf_{\rho\in\mathcal{M}} R(f_{\rho}) \le GL_{\psi}a_n + \xi_n. \tag{8.22}$$

当 $a_n \to 0$ 且 $\xi_n \to 0$ 具有分布无关速率时，对比较空间 $\{f_{\rho} : \rho \in \mathcal{M}\}$ 得到平均超额风险收敛。它非负，Markov 不等式进一步给出

$$\mathbb{P}\left\{R(f_{\rho_S}) - \inf_{\rho\in\mathcal{M}} R(f_{\rho}) > \varepsilon\right\} \le \frac{GL_{\psi}a_n + \xi_n}{\varepsilon}.$$

右侧不超过 $\delta$ 时便达到相应 PAC 保证。

最终若使用有限宽 $f_{\rho_{m,S}}$，还须把逼近 $\rho_S$ 造成的训练及总体风险误差加入式 (8.22)。无限神经元极限中的分布收敛，不能单独提供有限宽预测保证。

现在将随机单位由一个网络内的神经元，改为完整网络。$\rho$ 抽出单元后还需积分形成预测，下面的 $Q$ 抽取一次就得到完整预测器。因此要重新定义风险与参照分布。

### 8.5.3 完整网络分布与随机预测器泛化

令算法从 $S$ 得到完整参数上的 $Q_S$，预测时再抽参数。PAC–Bayes 将它与样本独立先验比较，给出对样本高概率成立的界；分布稳定性则与相邻样本的 $Q_{S'}$ 比较，控制平均泛化差。相对熵平均分解还可联系互信息，但不能合并两种概率保证。

**PAC–Bayes 风险界** 假设训练中心经验风险低，而且附近扰动网络也有低损失。要评价这组网络，我们可用样本依赖分布描述它，再同时计算随机网络的经验风险与相对事先分布的选择代价。这正是 PAC–Bayes 的比较方式。

**定义 8.18　PAC–Bayes 的先验与后验**　设 $\Theta$ 为完整网络的参数空间。先验 $P_0$ 是与样本 $S$ 独立的 $\Theta$ 上概率分布，后验 $Q_S$ 是由 $S$ 决定的 $\Theta$ 上概率分布。对于任意分布 $Q$，定义

$$\hat{R}_S(Q) = \mathbb{E}_{\theta\sim Q}\hat{R}_S(\theta), \qquad R(Q) = \mathbb{E}_{\theta\sim Q}R(\theta).$$

“后验”在此表示数据依赖分布，不要求按贝叶斯公式求出。评价先从 $Q$ 抽参数再预测，通常不等于均值参数网络风险。教学例子中，两网络经验错误率 0.02、0.10，后验概率 0.9、0.1，平均为 $0.9\times0.02+0.1\times0.10=0.028$。先验各赋 $1/2$ 时，信息代价为 $D_{\mathrm{KL}}(Q\|P_0)=0.9\log 1.8+0.1\log 0.2\approx 0.368$。经验风险评价预测，相对熵评价重新分配概率质量，二者各有作用。

为在有界风险间比较，定义 Bernoulli 相对熵 $\mathrm{kl}(a\|b)=a\log(a/b)+(1-a)\log((1-a)/(1-b))$，端点取连续延拓。下面使用便于完整推导的常数。

**定理 8.19　PAC–Bayes 期望风险界**　设 $(Z,\mathcal{Z})$ 为可测观测空间，$\mathcal{P}$ 为其上的概率分布，$(\Theta,\mathcal{T})$ 为参数空间。对每个 $\theta\in\Theta$，令 $z\mapsto\ell(\theta,z)$ 为可测的 $[0,1]$ 值损失，并假设联合映射 $(\theta,z)\mapsto\ell(\theta,z)$ 可测。令 $S=(z_1,\dots,z_n)\sim\mathcal{P}^n$，其中 $n\geq 1$，并定义

$$\hat{R}_S(\theta)=\frac{1}{n}\sum_{i=1}^{n}\ell(\theta,z_i), \qquad R(\theta)=\mathbb{E}_{z\sim\mathcal{P}}\ell(\theta,z).$$

对 $\Theta$ 上的任意概率分布 $Q$，定义

$$\hat{R}_S(Q) = \mathbb{E}_{\theta\sim Q}\hat{R}_S(\theta), \qquad R(Q) = \mathbb{E}_{\theta\sim Q}R(\theta).$$

对 $a,b\in[0,1]$，定义

$$\mathrm{kl}(a\|b)=a\log\frac{a}{b}+(1-a)\log\frac{1-a}{1-b},$$

端点按连续延拓解释。设先验 $P_0$ 为与 $S$ 独立的 $\Theta$ 上概率分布。对于任意 $\delta\in(0,1)$，以至少 $1-\delta$ 的概率，所有 $Q\ll P_0$ 同时满足

$$\mathrm{kl}\big(\hat{R}_S(Q)\|R(Q)\big)\leq\frac{D_{\mathrm{KL}}(Q\|P_0)+\log((n+1)/\delta)}{n}. \tag{8.23}$$

从而在同一事件上，

$$R(Q)\leq\hat{R}_S(Q)+\sqrt{\frac{D_{\mathrm{KL}}(Q\|P_0)+\log((n+1)/\delta)}{2n}}.$$

**证明** 固定参数 $\theta$，记其期望风险为 $r$。若单样本损失为 Bernoulli 变量，经验风险为 $k/n$ 的概率是 $\binom{n}{k} r^k (1-r)^{n-k}$，故

$$\mathbb{E}_S e^{n\,\mathrm{kl}(\hat{R}_S(\theta)\|r)} = \sum_{k=0}^{n} \binom{n}{k} \left(\frac{k}{n}\right)^k \left(1-\frac{k}{n}\right)^{n-k} \le n+1.$$

每一项都是某个二项分布取值于 $k$ 的概率，因而不超过 1。对一般 $[0,1]$ 损失，指数函数与相对熵的凸性允许逐个把损失替换成具有相同均值的 Bernoulli 端点变量，而不减小指数矩；因此上界仍然成立。

对独立先验积分，再使用 Markov 不等式，以至少 $1-\delta$ 的概率有

$$\mathbb{E}_{\theta\sim P_0} e^{n\,\mathrm{kl}(\hat{R}_S(\theta)\|R(\theta))} \le \frac{n+1}{\delta}.$$

在这个只由样本决定的事件上，对任意 $Q \ll P_0$ 使用换测度不等式

$$\mathbb{E}_Q g \le D_{\mathrm{KL}}(Q\|P_0) + \log \mathbb{E}_{P_0} e^{g}, \tag{8.24}$$

其推导见式 (7.12)。取 $g(\theta) = n\,\mathrm{kl}(\hat{R}_S(\theta)\|R(\theta))$，再由 kl 的联合凸性把左侧下界为 $n\,\mathrm{kl}(\hat{R}_S(Q)\|R(Q))$，即得第一式。最后使用 $\mathrm{kl}(a\|b) \ge 2(a-b)^2$ 得到第二式。 ■

Maurer 的精细指数矩估计可在相应条件下把 $n+1$ 换成 $2\sqrt{n}$[16]。当前形式展示了固定网络集中、先验积分与数据依赖后验三步。风险界还需小后验经验风险才有低总体风险；相对于假设空间的 PAC 学习则须进一步证明算法找到经验误差小且相对熵增长足够慢的后验。

[16] A. Maurer, *A Note on the PAC Bayesian Theorem*, 2004, arXiv: cs/0411099

若后验满足 $D_{\mathrm{KL}}(Q_S\|P_0) \le K$，我们可直接要求

$$2n\varepsilon^2 \ge K + \log((n+1)/\delta) \tag{8.25}$$

使经验风险外的代价不超过 $\varepsilon$。忽略 $n$ 的对数，充分样本量随 $(K+\log(1/\delta))/\varepsilon^2$ 增长。作为教学读界例子，经验风险至多 0.02、附加量至多 0.03，便以概率至少 $1-\delta$ 得到随机预测风险至多 0.05；这些数值不代表实测结果。

如果整个后验的平均经验风险为零，可直接利用 $\mathrm{kl}(0\|r) = -\log(1-r)$，在同一事件中得到

$$R(Q_S) \le 1 - \exp\!\left(-\frac{K+\log((n+1)/\delta)}{n}\right) \le \frac{K+\log((n+1)/\delta)}{n}.$$

此时充分条件为 $n\varepsilon \geq K + \log((n+1)/\delta)$。中心网络分类正确尚不足以使后验平均经验风险为零，因此不能据此直接使用该速率。

PAC–Bayes 用相对独立先验的代价 $K$ 衡量复杂度，大参数网络也可能有小代价，但须实际计算。构造后验时，扰动经验损失与信息代价需要共同控制；扩大低损失邻域或让后验贴近先验，都可能增加另一项。下面以高斯说明这个取舍。

连续先验下，在单个训练参数取点质量通常导致无限相对熵。改取 $Q = \mathcal{N}(\hat{\theta}, \sigma^2 \boldsymbol{I})$，将中心附近完整网络纳入评价。对 $p$ 维先验 $P_0 = \mathcal{N}(0, \tau^2 \boldsymbol{I})$，有

$$D_{\mathrm{KL}}(Q\|P_0) = \frac{\|\hat{\theta}\|_2^2}{2\tau^2} + \frac{p}{2}\left(\frac{\sigma^2}{\tau^2} - 1 - \log\frac{\sigma^2}{\tau^2}\right). \tag{8.26}$$

低损失邻域大时可以扩大后验，但方差代价在 $\sigma^2 = \tau^2$ 才最小，向两侧偏离都增加。因此平坦性需落实为扰动损失与相对熵比较；单看 Hessian 或谷宽仍受参数化影响[17]。

[17] L. Dinh, R. Pascanu, S. Bengio, Y. Bengio, *Sharp Minima Can Generalize for Deep Nets* In Proceedings of the 34th International Conference on Machine Learning, 2017, pp. 1019–1028

图 8.8固定坐标、方向和参数化，对比同等扰动的经验损失增幅。宽谷在此方向上增幅较小，说明局部扰动代价较低，尚需后验经验风险与先验代价共同支持泛化。重缩放坐标可以改变谷宽，所以截面宽窄不是函数本身不变的风险属性。

**后验分布的稳定性**　我们再改变参照对象：PAC–Bayes 比较 $Q_S$ 与固定 $P_0$，稳定性比较 $Q_S$ 与相邻样本产生的 $Q_{S'}$。接近固定先验并没有自动给出样本替换变化小的结论。

如果两个后验可以耦合为平均参数距离较小的网络对，且损失关于完整参数为 Lipschitz，就能控制随机预测器的平均损失差。下面将耦合距离直接接到泛化恒等式。

**定理 8.20　参数分布稳定性与期望泛化差**　设 $(Z, \mathcal{Z})$ 为可测观测空间，$\mathcal{P}$ 为其上的概率分布，$S = (z_1, \ldots, z_n) \sim \mathcal{P}^n$，其中 $n \geq 1$。参数空间 $\Omega \subseteq \mathbb{R}^p$ 取 Borel $\sigma$ 代数；可测随机学习算法根据 $S$ 输出具有有限一阶矩的概率分布 $Q_S$，再抽取 $\theta \sim Q_S$。设损失 $\ell : \Omega \times Z \to [0,1]$ 联合可测，并且对每个 $z \in Z$ 及任意 $\theta, \theta' \in \Omega$ 都有

$$|\ell(\theta, z) - \ell(\theta', z)| \leq L_\theta \|\theta - \theta'\|_2.$$

定义

$$R(\theta) = \mathbb{E}_{z\sim\mathcal{P}}\ell(\theta, z), \quad \hat{R}_S(\theta) = \frac{1}{n}\sum_{i=1}^{n}\ell(\theta, z_i),$$

$$R(Q) = \mathbb{E}_{\theta\sim Q}R(\theta), \qquad \hat{R}_S(Q) = \mathbb{E}_{\theta\sim Q}\hat{R}_S(\theta).$$

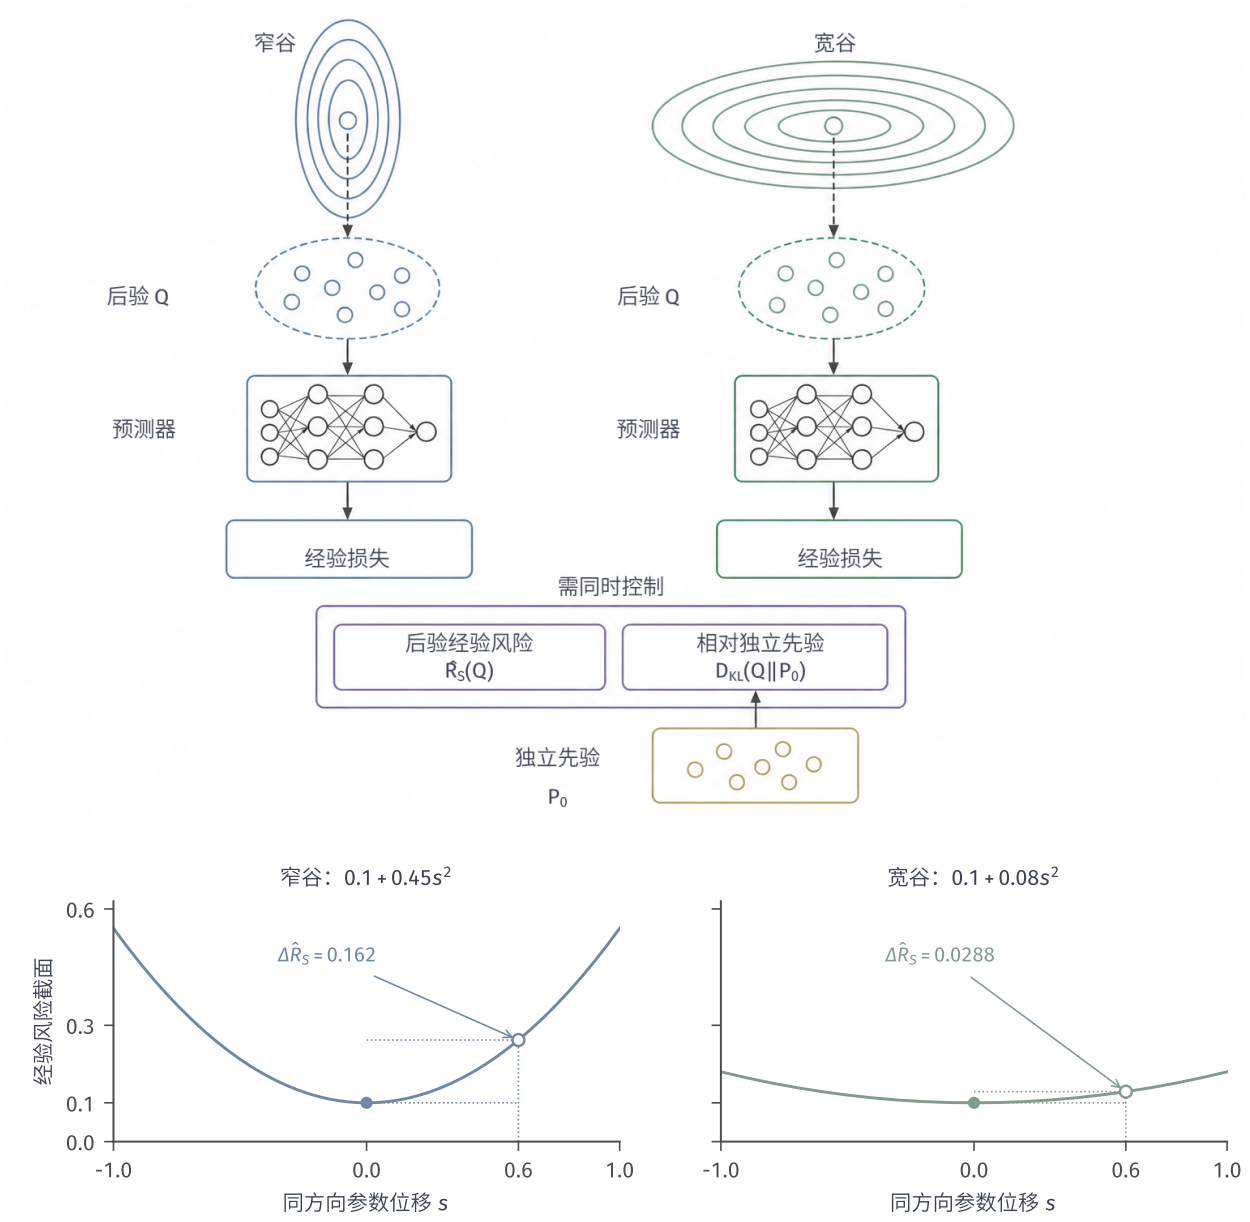


图 8.8 参数扰动代价与 PAC–Bayes 中的两项控制。上部示意窄谷、宽谷附近的参数扰动与随机预测器；在相应定理条件下，泛化保证还需同时控制后验经验风险与相对于独立先验的相对熵代价。下部两个面板共用相同横纵尺度，横轴为同一单位方向上的参数位移 $s$，即 $\theta = \hat{\theta} + s\boldsymbol{u}$、$\|\boldsymbol{u}\|_2 = 1$。构造的窄谷与宽谷分别为 $0.1 + 0.45s^2$、$0.1 + 0.08s^2$；实心点为谷底，空心点对应相同位移 $s = 0.6$，经验风险分别增加 0.162 和 0.0288。上部轮廓没有数值含义，下部曲线仅为可复算的教学构造。谷的宽度受参数化与坐标尺度影响，宽谷不必具有较小的期望风险。

其中 $L_\theta, \alpha_n \geq 0$。若任意仅替换一条观测所得的相邻样本 $S, S'$ 都满足 $W_1(Q_S, Q_{S'}) \leq \alpha_n$，则

$$\sup_z \left|\mathbb{E}_{Q_S}\ell(\theta, z) - \mathbb{E}_{Q_{S'}}\ell(\theta, z)\right| \leq L_\theta \alpha_n,$$

$$\left|\mathbb{E}_S[R(Q_S) - \hat{R}_S(Q_S)]\right| \leq L_\theta \alpha_n.$$

进一步，若 $\Theta \subseteq \Omega$ 为可测比较空间、$\rho_n \geq 0$、$Q_S(\Theta) = 1$ 几乎必然成立，且

$$\mathbb{E}_S\left[\hat{R}_S(Q_S) - \inf_{\theta\in\Theta} \hat{R}_S(\theta)\right] \leq \rho_n,$$

则 $\mathbb{E}_S R(Q_S) - \inf_{\theta\in\Theta} R(\theta) \leq L_\theta \alpha_n + \rho_n$。若这两个速率对所有允许分布一致趋于零，则得到相对于 $\Theta$ 的随机 PAC 学习保证。

**证明**　对任意配对分布 $\pi \in \Pi(Q_S, Q_{S'})$，损失期望之差的绝对值不超过

$$\mathbb{E}_\pi|\ell(\theta, z) - \ell(\theta', z)| \leq L_\theta \mathbb{E}_\pi\|\theta - \theta'\|_2.$$

对 $\pi$ 取下确界得到均匀稳定性，再由前章的替换样本恒等式得到期望泛化差。对于任意固定 $\theta \in \Theta$，近似 ERM 条件给出 $\mathbb{E}_S\hat{R}_S(Q_S) \leq R(\theta) + \rho_n$。加上泛化差并取下确界即得超额期望风险界。由于 $Q_S$ 以 $\Theta$ 为支撑，联合随机变量 $R(\theta) - \inf_{\vartheta\in\Theta} R(\vartheta)$ 非负，且

$$\mathbb{E}_{S,\theta\sim Q_S}\left[R(\theta) - \inf_{\vartheta\in\Theta} R(\vartheta)\right] = \mathbb{E}_S R(Q_S) - \inf_{\vartheta\in\Theta} R(\vartheta) \leq L_\theta\alpha_n + \rho_n.$$

对这个联合随机变量应用 Markov 不等式，失败概率至多 $(L_\theta\alpha_n + \rho_n)/\varepsilon$；令它不超过 $\delta$ 即得到同时包含样本和后验抽样随机性的 PAC 保证。 ■

已有 $W_1(Q_S, Q_{S'}) \leq c/n$ 和 $\rho_n \leq c'/\sqrt{n}$ 时，稳定性与经验最优性给出

$$\mathbb{E}_S R(Q_S) - \inf_{\theta\in\Theta} R(\theta) \leq \frac{L_\theta c}{n} + \frac{c'}{\sqrt{n}}.$$

例如 $n \geq \max\{2L_\theta c/\varepsilon,\ 4(c')^2/\varepsilon^2\}$ 足以使平均超额风险不超过 $\varepsilon$。这是对给定速率的条件推论，具体网络仍需训练分析来证明这些速率。

参数耦合难以估计时，还可比较相邻后验总变差。$[0,1]$ 损失的期望差不超过该距离，再由 $\sqrt{D_{\mathrm{KL}}(Q_S\|Q_{S'})/2}$ 控制。此处相对熵两端都是相邻后验，不能直接替换为后验—先验代价。

**相对熵与互信息** 若随机输出为 $W$、边缘分布为 $\bar{Q} = \mathbb{E}_S Q_S$，相关相对熵有限时有

$$\mathbb{E}_S D_{\mathrm{KL}}(Q_S \| P_0) = I(W;S) + D_{\mathrm{KL}}(\bar{Q} \| P_0). \tag{8.27}$$

将对数密度比分成 $\log(\mathrm{d}Q_S/\mathrm{d}\bar{Q})$ 和 $\log(\mathrm{d}\bar{Q}/\mathrm{d}P_0)$ 再平均，即得此式。第一项记录当前样本的信息，第二项记录总体输出与先验的偏离。它联系平均 PAC–Bayes 代价与信息稳定性，却没有把互信息的期望保证变为逐样本高概率保证。

若平均先验代价满足 $\mathbb{E}_S D_{\mathrm{KL}}(Q_S \| P_0) \le K_n$，第二项非负给出 $I(W;S) \le K_n$，定理 7.26便得到

$$\left| \mathbb{E}_S [R(Q_S) - \hat{R}_S(Q_S)] \right| \le \sqrt{\frac{K_n}{2n}}.$$

参数分布由此沿一般信息稳定性进入风险分解，再与经验最优性合并。PAC–Bayes 另给样本高概率事件中的同时后验保证，两种概率对象仍不同。

**两类参数分布的联系与边界** 回到随机单位，$\rho_S$ 抽取一次只得到一个神经元，式 (8.21)的积分才得到完整 $f_{\rho_S}$；$Q_S$ 则直接抽出完整网络。所以前者的风险评价确定积分函数，后者的 $R(Q_S)$ 平均多个完整函数的风险。

距离的用途也随单位而定。$W_1(\rho_S, \rho_{S'})$ 经单元 Lipschitz 性控制积分函数的稳定性，$W_1(Q_S, Q_{S'})$ 经完整参数 Lipschitz 性控制随机输出稳定性，$D_{\mathrm{KL}}(Q_S \| P_0)$ 则用于换测度的高概率界。任何一个小，都不会无条件使另外两个小。

可以在更高层让算法随机输出神经元分布，再以其完整积分预测器组成 PAC–Bayes 后验。但要重新定义随机对象、先验与损失，并核对可测性和绝对连续性。这并非平均场极限的直接结果。两条分支是不同的分析方式，而不是一个定理的两种表述。

## 8.6 理论的比较与使用

四个入口都要解释有限样本训练为何可能得到小期望风险，但分工不同：范数约束函数，初始梯度固定特征，更新选择解，分布再区分群体表示与完整网络随机化。表 8.1据此整理它们与一般学习工具的关系。复杂度、稳定性和 PAC–Bayes 是连接工具，不能再误列为互斥的上位入口。

这些界尚不具备直接数值排名的共同条件。范数间隔界评价分类错误，固定特征界评价有界 Lipschitz 损失，最小范数回归使用平方损失，PAC–Bayes 评价随机预测器。式 (8.11)还付出扰动代价才转回中心。因此必须先统一损失、输出与置信要求，再比较右侧。

| 分析入口 | 与一般学习理论的联系 | 期望风险与样本量由什么控制 | 对训练的指导 |
| --- | --- | --- | --- |
| 参数大小 | 函数空间复杂度控制泛化；分层参数变化也可转为损失稳定性 | 经验间隔错误率、范数与间隔之比、样本量及置信度 | 同时控制范数与经验间隔，不能只缩小权重 |
| 参数梯度初始值 | 固定特征接上 RKHS 复杂度、PAC–Bayes 与正则化稳定性 | 标签与核谱的关系、RKHS 范数、样本量和近似误差 | 检查初始特征能否以较小范数表达目标 |
| 参数梯度更新 | 动力学确定选解，再用风险分解、复杂度或稳定性控制泛化 | 最小范数解的数据依赖风险、归一化间隔、矩阵谱与样本敏感性 | 检查初始化、损失、参数化和优化器怎样共同选择解 |
| 参数分布 | 神经元分布通过稳定性分析确定性积分模型；完整网络分布通过 PAC–Bayes 或稳定性分析随机预测器 | 神经元分布变化、有限宽度误差、后验经验风险、相对熵代价与置信度 | 先区分 $\rho$ 与 $Q$ 的随机单位，再选择相应距离和泛化结论 |

表 8.1 神经网络泛化分析的四个入口。每一行对应本章一个上位分析角度；具体的复杂度界、稳定性定理和 PAC–Bayes 界是连接该角度与期望风险的工具。

同一训练结果可以沿多个入口分析。隐式偏差确定低范数选解后，范数间隔界可评价分类风险，样本稳定性则提供另一个保证。固定初始特征允许 RKHS 范数与正则化分析；特征明显变化时转向真实动力学或神经元分布。PAC–Bayes 也可评价结果附近网络，但其直接对象仍是对应随机预测器。

设计改变的对象须明确。范数约束限制候选空间，$\ell_2$ 惩罚修改目标，权重衰减在更新中收缩参数，初始化和优化器参与选解。PAC–Bayes 先验在观察当前样本前固定，可以只用于事后评价，不必用于训练。因此它们不是同一种假设空间限制。

更强约束还可能排除有用函数。缩小范数球可降低复杂度，却使目标不再可表示，即使达到类内最优风险仍留下近似误差。评价训练方案时，我们分别检查空间是否含低风险函数、算法是否达到低经验风险，以及输出是否满足泛化条件。现有工具支持这些判断，没有给出任意任务都适用的结构与训练选择法。

推算样本量时，先固定风险目标与可达到的经验误差，再求附加项足够小的 $n$。范数、间隔、稳定性与后验代价若随 $n$ 改变，都要一起代入。固定其他量得到的缩放仅是条件结论；上界空泛时需要更具体的分布和算法分析，不能把上界当成测试错误率。

## 8.7 本章小结

参数数量约束整个架构的容量，却不能独立解释某次过参数化训练的风险。我们还需确定算法所选函数，控制复杂度或样本敏感度，并核对近似能力和分布条件。VC 维提供固定架构的统计保证，选解分析则帮助评价架构内的具体结果。

范数与间隔限制函数复杂度，初始梯度在惰性条件下建立核特征，完整更新追踪经验解选择，参数分布分别组织神经元与随机网络。这些对象只有接到经验拟合、近似能力与样本量，才形成学习保证。核正定解决插值存在性，最小范数与最大间隔解决条件下的选解，平均场解决分布表示与极限，PAC–Bayes 解决随机后验风险；各自条件不能省略。

它们也能接到稳定性：范数限制变化的放大，动力学决定样本替换后的轨迹差，分布距离与信息量控制随机输出依赖。训练中的相邻迭代与相邻训练样本是不同的比较。沿稳定性得到学习还必须加入经验优化误差，复杂度与 PAC–Bayes 则提供另外的充分分析。

所有结论都绑定明确模型、数据和训练设定。规模、时间或任务一起改变时，须重新说明固定与变化对象。下一章进一步改变训练与评价分布，研究源域信息为何能够支持目标域预测。

**延伸阅读** Bartlett、Foster 与 Telgarsky 的谱归一化间隔分析展示各层范数和分类间隔怎样共同进入风险。可对照网络等价缩放，检查为何单独缩小权重或只报参数数目都不足以评价分类保证[18]。

Arora 等的两层网络分析适合追踪核谱与标签如何同时影响训练和风险；Soudry 等的可分分类分析则说明逻辑参数发散时方向为何仍趋向最大间隔[19,20]。

Maurer 的 PAC–Bayes 推导可用于核对先验积分、指数矩和换测度步骤，尤其可比较更精细常数需要哪些条件[21]。

Razin 与 Cohen 的矩阵分解反例展示范数解释的边界：训练偏好可能无法由固定矩阵范数完整表示，可结合前面的谱动力学与静态范数引理对照[22]。

[18] P. L. Bartlett, D. J. Foster, M. J. Telgarsky, *Spectrally-Normalized Margin Bounds for Neural Networks* In Advances in Neural Information Processing Systems 30, 2017

[19] S. Arora, S. S. Du, W. Hu, Z. Li, R. Wang, *Fine-Grained Analysis of Optimization and Generalization for Overparameterized Two-Layer Neural Networks* In Proceedings of the 36th International Conference on Machine Learning, 2019, pp. 322–332

[20] D. Soudry, E. Hoffer, M. S. Nacson, S. Gunasekar, N. Srebro, *The Implicit Bias of Gradient Descent on Separable Data* In Journal of Machine Learning Research, 2018, vol. 19, no. 70, pp. 1–57

[21] A. Maurer, *A Note on the PAC Bayesian Theorem*, 2004, arXiv: cs/0411099

[22] N. Razin, N. Cohen, *Implicit Regularization in Deep Learning May Not Be Explainable by Norms* In Advances in Neural Information Processing Systems, 2020

第 9 章

# 迁移学习的可学习性

设邮件分类器在过去几个月的数据上达到预定损失容限。前面各章说明了如何由复杂度或稳定性，把这项经验评价接到同分布新邮件的期望风险。换到新月份后，邮件类型的比例、同一输入的标签规律都可能改变，评价分布也随之改变。即使过去样本很多，同分布保证仍需重新检查，才能用于新月份。

我们首先要判断源域观测能否确定目标域预测，再研究有限样本怎样估计所需信息。第一步需要跨域标签与输入的联系，第二步需要控制候选空间或算法选择。VC 维、范数、参数分布和稳定性可以完成有限样本分析，却不能单独补出缺失的目标标签关系。

第 9.1节先固定算法看见的数据、目标风险及允许偏移，并用不可识别反例检查信息门槛。目标输入可见时，第 9.2节连接跨域风险，再加入复杂度或稳定性。目标输入也不可见时，第 9.3节分别以共享标签机制和随机环境抽样建立保证。逐目标域与环境平均的评价对象不同，将在各自定义和结论中保留。

## 9.1 迁移学习的学习问题

### 9.1.1 数据与评价目标

沿用第 3.5.3节，迁移学习用已有领域或任务的信息帮助新问题。这里固定输入空间 $X$ 与标签空间 $Y$，只让 $X\times Y$ 上的联合分布改变，将该分布称为一个域。跨任务以及空间改变不属于后面形式结论。过去月份提供数据，是源域；新月份需要预测，是目标域。

为了在同一评价标准下比较两域，记联合分布为 $\mathcal{P}_S,\mathcal{P}_T$，观测空间仍为 $Z=X\times Y$。固定假设空间 $\mathcal{H}$ 和 $[0,1]$ 值预测损失 $\ell(\hat{y},y)$，令 $\ell_h(x,y)=\ell(h(x),y)$，对 $z=(x,y)\in Z$ 亦记 $\ell(h,z)=\ell(h(x),y)$。同一 $h$ 的两域风险为

$$R_S(h)=\mathbb{E}_{\mathcal{P}_S}\ell_h(x,y),\qquad R_T(h)=\mathbb{E}_{\mathcal{P}_T}\ell_h(x,y). \tag{9.1}$$

下标表示域，帽号 $\hat{R}$ 才表示经验评价；域 $D$ 的输入边缘记作 $\mathcal{P}_D^X$。全章假定损失、上确界与抽样过程满足所需可测性条件。

部署评价采用 $R_T$，并与 $R_{T,\mathcal{H}}^\star = \inf_{h\in\mathcal{H}} R_T(h)$ 比较，即同一空间在目标域的最低风险。差 $R_T(h) - R_{T,\mathcal{H}}^\star$ 称为**目标域超额期望风险**（target-domain excess risk）。最低值可以非零，学习只要求接近它，不承诺消除输入信息不足造成的错误。

现在固定训练信息。**领域自适应**（domain adaptation）允许目标域样本参与学习；无监督版本观察带标签源样本 $S_S$ 和无标签目标输入 $U_T$，两者独立且

$$S_S \sim \mathcal{P}_S^{n_S}, \qquad U_T \sim (\mathcal{P}_T^X)^{n_T}.$$

目标输入能够说明边缘分布，却没有目标标签。目标标签足够时可直接应用同域 PAC 理论，迁移分析则进一步判断源域信息能否减少这些标签需求。

领域泛化（domain generalization）连目标域样本也不用于训练与模型选择，只从若干训练环境的带标签数据得到固定假设。预测当然需要读入新输入，这里禁止的是利用目标样本更新或选模型。若部署时用目标批次更新参数、归一化统计量或选择结果，就转为第 3.5.3节的测试时适应；输出变成适应算法，时序、批次依赖和比较基准也要重定，不能直接使用固定输出定理。没有目标数据时，还需规定哪些新环境属于允许范围。

相同损失下，训练信息与概率对象进一步给出三种问题。领域自适应固定源—目标分布对，算法由 $S_S, U_T$ 选择供该目标使用的假设。它评价 $R_T$ 并与 $R_{T,\mathcal{H}}^\star$ 比较，概率来自两批样本及算法随机性。

**逐目标域领域泛化**（target-wise domain generalization）固定训练域组，对每个允许目标域分别要求保证。输出只依赖训练域样本，不能为该目标重新选择；风险与基准仍为 $R_T, R_{T,\mathcal{H}}^\star$。概率平均训练样本和算法随机性，目标域是外层给定对象。

**环境平均领域泛化**（environment-average domain generalization）则假设环境来自总体 $\mathcal{Q}$，抽取 $K$ 个训练环境后再在域内采样。共同输出评价 $R_{\mathcal{Q}}(h) = \mathbb{E}_{\mathcal{P}\sim\mathcal{Q}} R_{\mathcal{P}}(h)$，与 $\inf_{h\in\mathcal{H}} R_{\mathcal{Q}}(h)$ 比较。概率包含环境、环境内观测及算法随机性。三种问题沿用同一损失与输出范围，却改变可见信息、分布对象和比较基准。

### 9.1.2 分布偏移与可识别性

标签是否仍可迁移，需要在联合分布中说明。两域若保留给定输入后的标签规律，源标签可以提供联系；标签规律若任意改变，源样本再多也无法确定目标分类。下面按保留的组成部分规定偏移。尤其在源域未见输入处，条件分布版本并非源数据所能确定，协变量偏移还须结合覆盖。

**定义 9.1 协变量偏移** 若存在一个条件标签分布 $\mathsf{K}(\mathrm{d}y \mid x)$，使得

$$\mathcal{P}_D(\mathrm{d}x, \mathrm{d}y) = \mathcal{P}_D^X(\mathrm{d}x)\mathsf{K}(\mathrm{d}y \mid x), \qquad D \in \{S, T\},$$

则称两域满足协变量偏移设定。该设定允许 $\mathcal{P}_S^X$ 与 $\mathcal{P}_T^X$ 不同。

协变量偏移（covariate shift）让输入频率改变、条件标签分布保持。例如新月份长邮件更多，但长、短邮件内部的诈骗比例各自不变。分类器若更容易错判长邮件，比例增加仍可提高目标风险。因此保留标签规律没有要求两域风险相等。

**定义 9.2 标签偏移** 若存在条件输入分布 $\mathsf{K}(\mathrm{d}x \mid y)$，使得

$$\mathcal{P}_D(\mathrm{d}x, \mathrm{d}y) = \mathcal{P}_D^Y(\mathrm{d}y)\mathsf{K}(\mathrm{d}x \mid y), \qquad D \in \{S, T\},$$

则称两域满足标签偏移设定。该设定允许 $\mathcal{P}_S^Y$ 与 $\mathcal{P}_T^Y$ 不同。

标签偏移（label shift）保留类别内部输入分布，改变类别比例。例如诈骗邮件更常见，但诈骗与正常邮件各自的特征分布不变。按输入反推类别时还要计类别比例，所以给定输入的标签概率通常也会改变；这与协变量偏移保留的条件不同。

**概念偏移**（concept shift），亦称条件偏移，直接描述给定输入的标签分布改变。源域长邮件诈骗比例 0.1、目标为 0.4，即使长邮件频率不变，源标签也不能直接代表目标。本章在共同覆盖输入上比较这类变化；源域完全未覆盖的目标输入另有信息缺口。

三种设定描述保留或改变的组成部分，并非互斥类别。标签偏移保留 $\mathcal{P}(x \mid y)$，比例变化通常又改变 $\mathcal{P}(y \mid x)$，所以也可出现概念偏移描述的变化。图 9.1定位这些组成部分，但没有证明可学习：协变量偏移还未保证源覆盖目标，标签偏移也未保证类别比例可由输入唯一确定。

改变输入密度与是否覆盖目标区域，是两个不同条件。图 9.2以同一尺度比较：目标支持在源支持内时，目标区域原则上可取得源观测；区域没有源概率时，增加源数据不会获得其标签。即使覆盖完整，源概率很小还会造成后面的过大密度比。

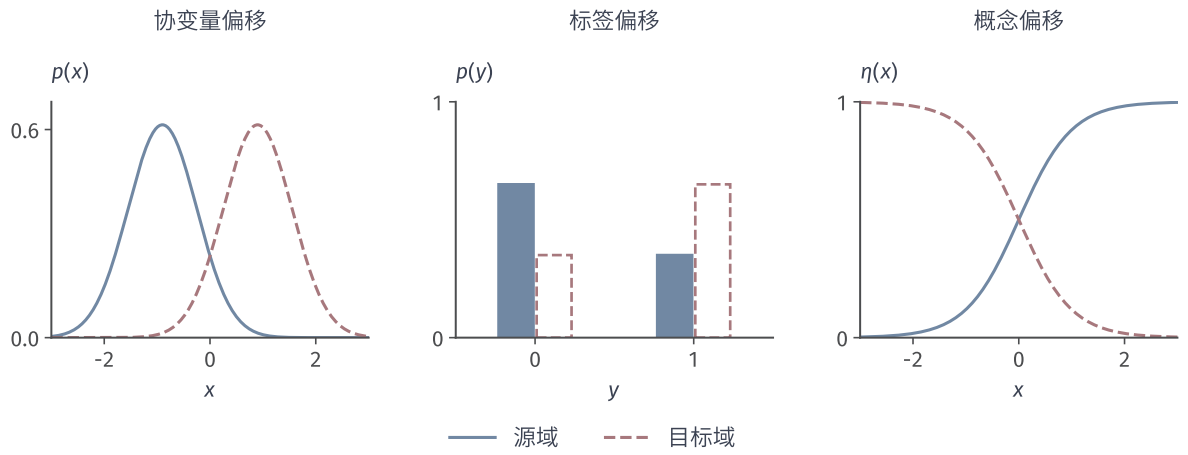


图 9.1 分布偏移改变联合分布的不同组成部分。实线表示源域，虚线表示目标域；密度、类别比例和条件概率均为规范化的教学构造，不表示实测频率。协变量偏移允许输入分布改变，标签偏移允许类别比例改变，概念偏移则改变给定输入后的标签分布，图中 $\eta(x) = \mathbb{P}(y = 1 \mid x)$。这些设定还需与覆盖条件或其他可识别条件结合，才能支持迁移保证。

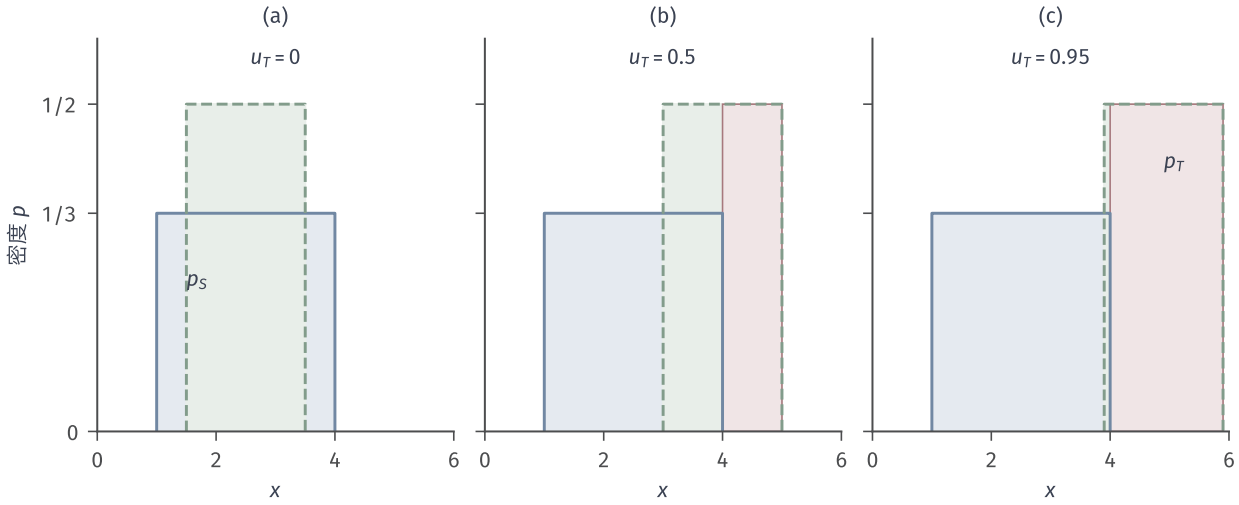


图 9.2 同尺度的三种支持覆盖。源密度均为 $[1,4]$ 上的 $1/3$，目标密度均为长度 2 区间上的 $1/2$；(a)、(b)、(c) 的目标支持依次为 $[1.5, 3.5]$、$[3, 5]$、$[3.9, 5.9]$。深色区域没有源密度，其目标概率 $u_T = \mathbb{P}_T\{p_S(X) = 0\}$ 依次为 0、0.5、0.95。实线、虚线与底色共同区分源域、目标域；只有 (a) 满足覆盖条件 $p_T(x) > 0 \Rightarrow p_S(x) > 0$。密度为规范化教学构造，不是实验分布。

图 9.3进一步固定相同输入分布，让隐藏目标标签取两种相反规律。算法可见数据仍相同，所以输入或表示对齐不足以确定目标预测。

这一缺口不同于样本量不足。相同观测分布的允许机制必须给出相同目标泛函，目标才可识别（可参考第一卷“随机变量”章的目标可识别性定义）。这里目标可为标签核、最优决策或风险；若可见源标签和目标输入相同，目标规律却不同，算法无法区分。下面以小假设空间把**可识别性**（identifiability）与容量分开。

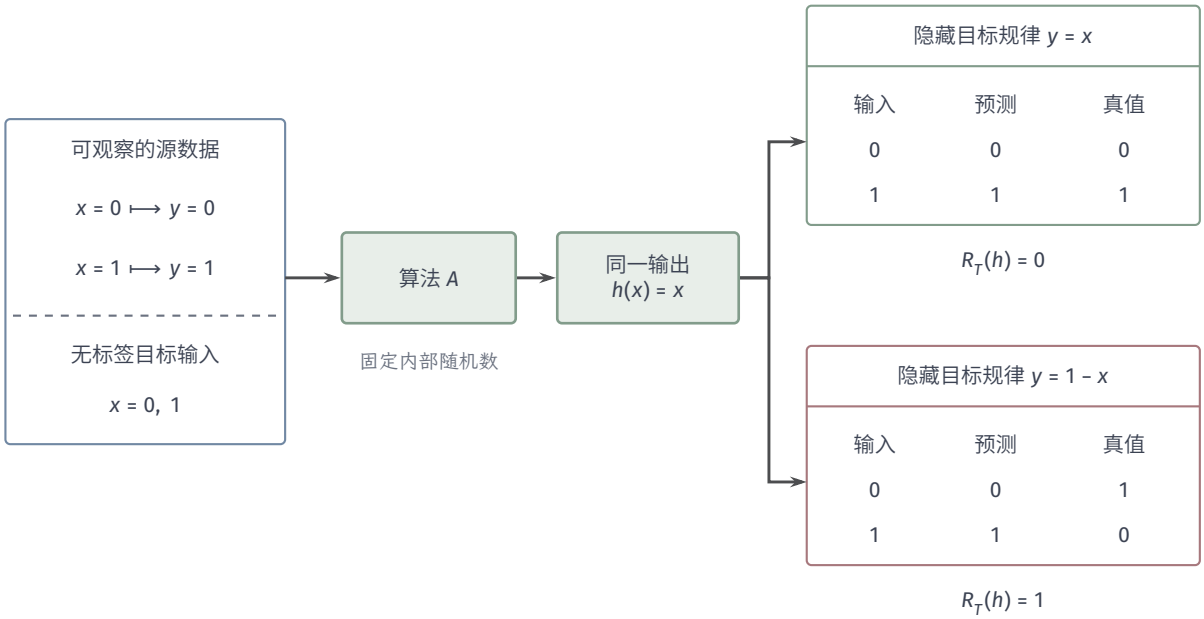


图 9.3　相同可观察数据不能区分两种目标规律。两域都以概率 $1/2$ 产生输入 0 或 1，源标签为 $y = x$。算法只收到左侧带标签源样本和无标签目标输入，目标标签并未提供；右侧两种可能分别取 $y = x$ 与 $y = 1 - x$。固定算法内部随机数后，两种情形必得到同一输出。图中以 $h(x) = x$ 为例，两张表逐点对照同一预测与隐藏标签：零一损失下，源风险为 0，两种目标风险分别为 0、1。任意二分类输出在这两种目标规律下的风险之和为 1。输入完全对齐仍未提供选择目标规律的证据，还需目标标签或连接两域标签规律的额外条件。

**定理 9.3　缺少覆盖时的不可学习性**　采用二分类零一损失。令 $X = \{a, b\}$、$Y = \{0, 1\}$，且 $\mathcal{H} = \{h_0, h_1\}$ 满足

$$h_0(a) = h_1(a) = 0, \qquad h_0(b) = 0, \quad h_1(b) = 1.$$

源域分布 $\mathcal{P}_S$ 恒产生 $(a, 0)$，目标域输入边缘分布恒产生 $b$。允许的两个目标域分布 $\mathcal{P}_T$ 分别令 $b$ 的标签恒为 0 或恒为 1，并定义 $R_T(h) = \mathbb{P}_{(x,y)\sim\mathcal{P}_T}\{h(x) \neq y\}$。对任意 $n_S, n_T \geq 1$，令 $S_S \sim \mathcal{P}_S^{n_S}$、$U_T \sim (\mathcal{P}_T^X)^{n_T}$ 相互独立。对任意只使用带标签源域样本与无标签目标域样本、输出属于 $\mathcal{H}$ 的可能随机化学习算法 $A$，无论两类样本量多大，总有一个允许的目标域满足

$$\mathbb{P}_{S_S, U_T, A}\left(R_T(A(S_S, U_T)) > \frac{1}{4}\right) \geq \frac{1}{2}.$$

这里概率包含抽样与算法内部的随机性。两个设定各自都存在源域与目标域期望风险同时为零的假设。

**证明** 两种设定中，算法收到的全部源域样本都是 $(a,0)$，全部目标域输入都是 $b$，因此输入数据的分布完全相同。设算法输出 $h_1$ 的概率为 $p$；这个概率只可能来自算法内部随机性，且在两个设定中相同。目标标签为 0 时，算法以概率 $p$ 输出 $h_1$，其目标域零一风险为 1；目标标签为 1 时，算法以概率 $1-p$ 输出 $h_0$，其目标域零一风险也为 1。两者至少有一个不小于 $1/2$。标签为 0 的设定中 $h_0$ 在两域均无错误，标签为 1 的设定中 $h_1$ 在两域均无错误，故失败并非假设空间缺少合适的假设。 ■

例中只有两个假设，VC 维为 1，但 $b$ 的标签在源域从不出现，任何源样本量都不能补足。每种设定也可以定义一个两域共享的标签机制；缺的是源输入对 $b$ 的覆盖。因此参数数目或范数限制尚不足够，还需同时检查跨域联系与可见信息[1]。

[1] S. Ben-David, T. Lu, T. Luu, D. Pál, *Impossibility Theorems for Domain Adaptation* In Proceedings of the Thirteenth International Conference on Artificial Intelligence and Statistics, 2010, pp. 129–136

### 9.1.3 迁移学习的 PAC 要求

为了排除或容纳这些反例，我们必须固定允许分布对的集合 $\mathfrak{P}_{\mathrm{DA}}$。共享标签核、覆盖程度、算法已知信息都属于问题条件。改变这些条件，即使 $\mathcal{H}$ 相同，也可能改变可学习性。

**定义 9.4 相对于分布族的领域自适应 PAC 可学习性** 固定 $\mathcal{H}$、损失函数 $\ell$ 及允许的分布对集合 $\mathfrak{P}_{\mathrm{DA}}$。若存在取值于 $\mathcal{H}$ 的学习算法 $A$ 与有限的样本量函数 $m_S, m_T$，使得对任意 $\varepsilon,\delta\in(0,1)$、任意 $(\mathcal{P}_S,\mathcal{P}_T)\in\mathfrak{P}_{\mathrm{DA}}$，以及 $n_S\geq m_S(\varepsilon,\delta)$、$n_T\geq m_T(\varepsilon,\delta)$，都有

$$\mathbb{P}_{S_S,U_T,A}\Big(R_T(A(S_S,U_T))-R^{\star}_{T,\mathcal{H}}\leq\varepsilon\Big)\geq 1-\delta,$$

则称 $\mathcal{H}$ 在该设定下是领域自适应 PAC 可学习的。样本量函数可以依赖 $\mathcal{H}$ 及 $\mathfrak{P}_{\mathrm{DA}}$ 的统一参数，但不能依赖其中未知的具体分布对。

定义要求输出属于 $\mathcal{H}$，但不要求目标最优风险为零，是不可知学习。密度比等已知辅助量还须列为算法输入。这里只问统计存在性，能否高效寻找输出属于另一个计算问题。

**定义 9.5 逐目标域领域泛化 PAC 可学习性** 设 $\mathfrak{P}_{\mathrm{DG}}$ 是允许训练域组 $\mathcal{D}=(\mathcal{P}_1,\dots,\mathcal{P}_K)$ 的集合，并为每个 $\mathcal{D}$ 指定允许目标域集合 $\mathcal{T}(\mathcal{D})$。记训练域均匀混合为 $\overline{\mathcal{P}}_{\mathcal{D}}=K^{-1}\sum_{e=1}^{K}\mathcal{P}_e$。若存在取值于 $\mathcal{H}$ 的算法 $A$

和有限样本量函数 $m$，使对任意 $\varepsilon,\delta\in(0,1)$、任意 $\mathcal{D}\in\mathfrak{P}_{\mathrm{DG}}$、任意固定的 $\mathcal{P}_T\in\mathcal{T}(\mathcal{D})$ 及任意 $n\ge m(\varepsilon,\delta)$，都有

$$\mathbb{P}_{S\sim\overline{\mathcal{P}}_{\mathcal{D}}^{n},A}\Big(R_T(A(S))-R^{\star}_{T,\mathcal{H}}\le\varepsilon\Big)\ge 1-\delta,$$

则称 $\mathcal{H}$ 在该设定下是**逐目标域领域泛化**（target-wise domain generalization）PAC 可学习的。算法在训练和模型选择时不接收目标域样本；目标域由概率之外的全称量词固定。

同一算法和门槛须适用于每个允许目标域，但各域的成功事件可以不同。若某项定理在同一个样本事件上覆盖全部目标域，它比此处逐域定义更强。

**定义 9.6　环境平均领域泛化 PAC 可学习性**　设 $\mathfrak{M}$ 是允许的环境分布族，其中每个 $Q\in\mathfrak{M}$ 都定义在 $Z$ 上的概率分布所组成的空间上。训练时先独立抽取 $\mathcal{P}_1,\dots,\mathcal{P}_K\sim Q$，再从每个环境抽取数据块 $D_e\sim\mathcal{P}_e^{n}$，算法只接收 $\mathcal{S}=(D_1,\dots,D_K)$。定义

$$R_Q(h)=\mathbb{E}_{\mathcal{P}\sim Q}R_{\mathcal{P}}(h).$$

若存在取值于 $\mathcal{H}$ 的算法 $A$ 以及有限的环境数门槛 $k_0$ 和总观测数门槛 $m_0$，使对任意 $\varepsilon,\delta\in(0,1)$、任意 $Q\in\mathfrak{M}$，只要 $K\ge k_0(\varepsilon,\delta)$ 且 $Kn\ge m_0(\varepsilon,\delta)$，就有

$$\mathbb{P}_{\mathcal{P}_1,\dots,\mathcal{P}_K,D_1,\dots,D_K,A}\Big(R_Q(A(\mathcal{S}))-\inf_{h\in\mathcal{H}}R_Q(h)\le\varepsilon\Big)\ge 1-\delta,$$

则称 $\mathcal{H}$ 在该设定下是**环境平均领域泛化**（environment-average domain generalization）PAC 可学习的。

环境平均的概率包括训练环境和域内观测，未来环境则已在 $R_Q$ 中平均。基准是一个共同假设的最低平均风险，不是每个环境各选最佳后再平均。定义 9.6还要求相应超额风险随两层样本量增加任意减小。

三种 PAC 目标都须绑定分布族。如果风险界留有固定正偏移项，它仍能揭示影响因素，却不能保证任意精度。后面的结论将分别固定自适应、逐目标或环境平均的评价对象。

## 9.2　领域自适应的可学习性

自适应中的无标签目标样本只显示输入分布。因此我们先要把源标签风险与目标风险连接，再控制有限抽样和算法选择。分歧、标签核和覆盖提供

前一步，函数空间复杂度或输出稳定性提供后一步。只有两步成立，VC 维、Rademacher、稳定性或 PAC–Bayes 才支持目标保证。

### 9.2.1 跨域风险的连接与可识别条件

二分类器的预测分歧无需标签即可观察。例如两分类器在源域 10% 输入、目标域 40% 输入上意见不同，分歧概率相差 0.3。源分歧为 0.1 没有单独限制目标分歧，所以跨域风险比较需要保留这项变化。

观察样本后会选择不同假设，因此不能只控制某一对。我们对 $\mathcal{H}$ 全部假设对取两域分歧概率的最大差，得到 $\mathcal{H} \triangle \mathcal{H}$ 散度（$\mathcal{H} \triangle \mathcal{H}$-divergence），亦称假设分歧散度。上确界覆盖所有可能选择，前置系数 2 采用惯用定义。

**定义 9.7　假设分歧散度**　对非空二分类假设空间 $\mathcal{H} \subseteq \{0,1\}^X$，定义

$$d_{\mathcal{H}\triangle\mathcal{H}}(\mathcal{P}_S^X, \mathcal{P}_T^X) = 2 \sup_{h,g\in\mathcal{H}} \Big| \mathbb{P}_{x\sim\mathcal{P}_S^X}(h(x) \neq g(x)) - \mathbb{P}_{x\sim\mathcal{P}_T^X}(h(x) \neq g(x)) \Big|. \tag{9.2}$$

还可给输入加域来源标签，令分类器类 $\mathcal{G}$ 识别来源。定义 $d_{\mathcal{G}} = 2\sup_{g\in\mathcal{G}} |\mathbb{P}_S(g = 1) - \mathbb{P}_T(g = 1)|$；两域先验相等且 $\mathcal{G}$ 对补封闭时，最低域错误满足 $d_{\mathcal{G}} = 2(1 - 2\varepsilon^*_{\mathrm{dom}})$。域错误越小，说明候选类越能找到概率不同的区域，因此散度越大。这是总体可分性，不含抽样或计算保证。取 $\mathcal{G} = \mathcal{H}$ 得到 $\mathcal{H}$ 散度，取 $\mathcal{G} = \mathcal{H} \triangle \mathcal{H}$ 才对应式 (9.2)。图 9.4同时保留这项区别与任务风险的三项来源。

分歧之外还需共同预测能力。令 $\lambda = \inf_{g\in\mathcal{H}}(R_S(g) + R_T(g))$，它衡量同一假设能否同时在两域取得小风险，由分布与空间决定，与正则系数无关。Ben-David 等将这一标签相关量与源风险、输入分歧联系起来[2]。

**定理 9.8　领域自适应的目标域期望风险界**　设 $(X, \mathcal{X})$ 为可测输入空间，$Y = \{0,1\}$，$\mathcal{P}_S, \mathcal{P}_T$ 为 $X \times Y$ 上的概率分布，其输入边缘分布分别为 $\mathcal{P}_S^X, \mathcal{P}_T^X$。令 $\mathcal{H}$ 为由可测函数 $h : X \to Y$ 组成的非空二分类假设空间，并定义

$$R_D(h) = \mathbb{P}_{(x,y)\sim\mathcal{P}_D}\{h(x) \neq y\}, \qquad D \in \{S, T\},$$

$$d_{\mathcal{H}\triangle\mathcal{H}}(\mathcal{P}_S^X, \mathcal{P}_T^X) = 2 \sup_{h,g\in\mathcal{H}} \Big| \mathbb{P}_{x\sim\mathcal{P}_S^X}\{h(x) \neq g(x)\} - \mathbb{P}_{x\sim\mathcal{P}_T^X}\{h(x) \neq g(x)\} \Big|,$$

[2] S. Ben-David, J. Blitzer, K. Crammer, A. Kulesza, F. Pereira, J. W. Vaughan, *A Theory of Learning from Different Domains* In Machine Learning, 2010, vol. 79, pp. 151–175

以及

$$\lambda = \inf_{g \in \mathcal{H}} \big( R_S(g) + R_T(g) \big).$$

则对任意 $h \in \mathcal{H}$，

$$R_T(h) \le R_S(h) + \frac{1}{2} d_{\mathcal{H}\triangle\mathcal{H}}(\mathcal{P}_S^X, \mathcal{P}_T^X) + \lambda. \tag{9.3}$$

**证明** 取任意用于比较的假设 $g \in \mathcal{H}$。当 $h$ 在目标域预测错误时，要么 $g$ 也预测错误，要么 $h$ 与 $g$ 的预测不同。因此

$$R_T(h) \le R_T(g) + \mathbb{P}_T(h(x) \neq g(x)).$$

分歧散度控制同一分歧事件在两域的概率差，从而

$$\mathbb{P}_T(h \neq g) \le \mathbb{P}_S(h \neq g) + \frac{1}{2} d_{\mathcal{H}\triangle\mathcal{H}}.$$

在源域中，两个二分类假设预测不同意味着至少一个预测错误，故 $\mathbb{P}_S(h \neq g) \le R_S(h) + R_S(g)$。合并三步，再对 $g$ 取下确界，得到结论。 ■

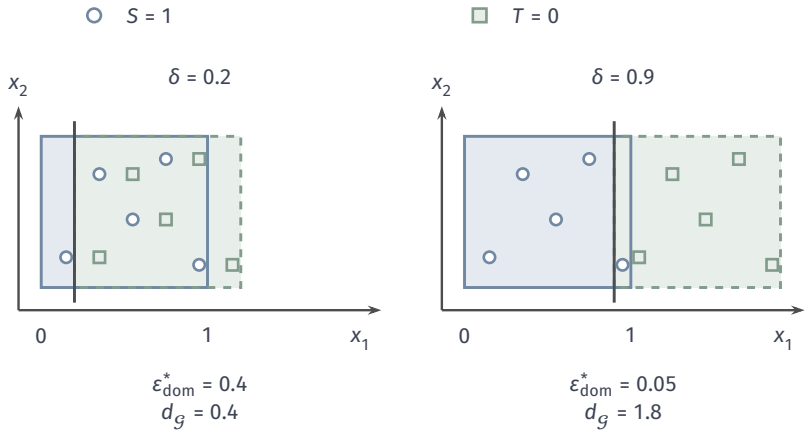


图 9.4 域分类器的错误只对应输入散度项。源输入均匀分布于 $[0,1]^2$，目标输入均匀分布于 $[\delta, 1+\delta]\times[0,1]$，其中 $0 \le \delta \le 1$；圆点、方块的位置为教学构造，错误率由区域概率计算。$\mathcal{H}$ 含双向阈值与常值假设，域分类器类取 $\mathcal{G} = \mathcal{H} \triangle \mathcal{H}$。其中 $g = h_0 \oplus h_\delta$ 在左侧浅色带预测源域，$h_a(x) = \mathbb{I}\{x_1 \ge a\}$；两域均等先验时，最小域错误为 $(1-\delta)/2$，$d_{\mathcal{G}} = 2\delta$。任务风险界还包含源风险及 $\lambda = \inf_{h\in\mathcal{H}}(R_S(h) + R_T(h))$，不能只由域错误决定。

共同错误 $\lambda$ 包含目标标签，无标签输入不能直接估计它。要让目标超额风险趋零，我们需进一步规定可用于学习的跨域关系。下面采用共享条件标签、源覆盖目标输入及统一有界密度比，将目标风险转换成可估计的源风险。

目标输入分布对源输入分布绝对连续时，在目标分布下可积函数的期望可以写成源分布下的加权期望。密度比存在仍不保证有界或具有有限二阶矩，因此估计还需核对权重的大小（可参考第一卷“随机变量”章的“概率加权下的分布变换”一节）。源标签和目标输入的观测规律也不能单独识别目标标签核，迁移仍依赖连接两域的条件（可参考第一卷“数学基础与后续研究”章的“跨分布学习”一节）。记目标输入相对源输入的密度比为 $w(x)$，一般地，它是对每个可测 $B$ 满足 $\mathcal{P}_T^X(B) = \int_B w(x)\,\mathrm{d}\mathcal{P}_S^X(x)$ 的非负函数。若几乎处处 $w(x) \le \kappa$，则

$$\mathcal{P}_T^X(B) \le \kappa \mathcal{P}_S^X(B).$$

它既排除源完全遗漏区域，也限制源低估目标重要区域的程度。目标某类邮件占一半、源仅百分之一时，必有 $\kappa \ge 50$；这类稀少源观测会增加估计难度。

共享标签核使输入重加权同时重加权标签损失，因此目标评价可写为

$$R_T(h) = \mathbb{E}_{(x,y)\sim\mathcal{P}_S}[w(x)\ell(h(x),y)]. \tag{9.4}$$

图 9.5显示目标相对常见的输入获得更大源样本权重。标签仍由源域提供，其适用性靠共享条件机制，而非输入密度接近。

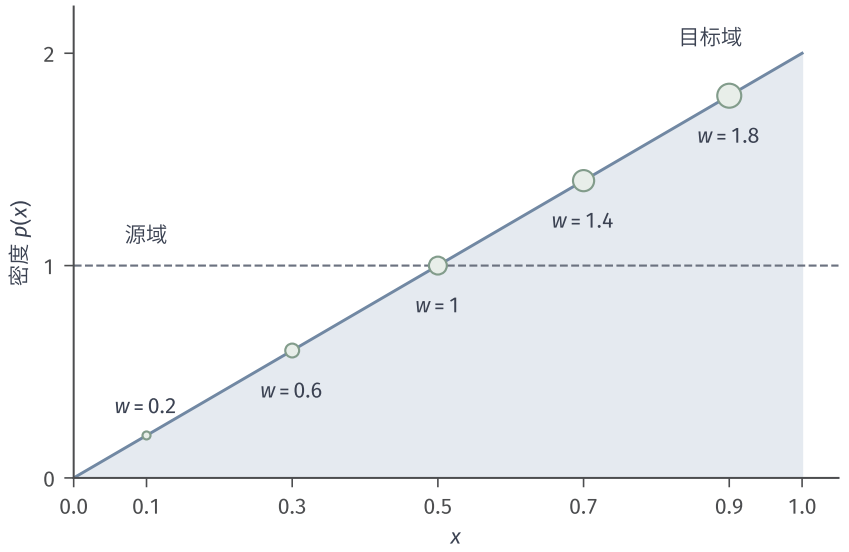


图 9.5　重要性权重重新分配源样本的贡献。在 $[0,1]$ 上构造源密度 $p_S(x) = 1$、目标密度 $p_T(x) = 2x$，二者均积分为 1，因此 $w(x) = 2x$。五个源样本位置人为取为 0.1、0.3、0.5、0.7、0.9，权重依次为 0.2、0.6、1、1.4、1.8。圆点叠在目标密度上，面积与权重成正比，面积不表示局部样本数量。目标输入必须受到源输入覆盖；要使用风险恒等式，还需保持相同的条件标签分布。

等式只替换输入测度，条件标签核保持不变。它让无法直接观测的目标标签损失成为源域可估计期望。我们先令 $w$ 已知，给出明确可学习族，再讨论未知比值的额外估计要求。

### 9.2.2 基于假设空间的有限样本保证

现在固定前面的两类连接：分歧风险界保留共同错误项，加权恒等式依赖共享核和覆盖。接下来从整个函数空间控制经验偏差。VC 维适合二分类与分歧函数，加权实值损失则可用 Rademacher 复杂度和范数。

**分歧距离与 VC 维**　总体分歧界还没有样本量。带标签源数据估计源风险，两域输入估计分歧概率；为评价数据依赖的最终假设，估计需同时覆盖全部假设与假设对。

将源经验风险记为 $\widehat{R}_{S_S}(h)$，用样本频率替换式 (9.2)中的概率得到 $\widehat{d}$。分歧函数组成

$$\mathcal{D}_{\mathcal{H}} = \{x \mapsto \mathbb{I}\{h(x) \neq g(x)\} : h, g \in \mathcal{H}\}.$$

这将假设对比较变成二值函数估计。分别用 $c_{\mathcal{H}}(n,\delta)$ 和 $c_{\mathcal{D}}(n,\delta)$ 控制分类与分歧的统一偏差，即可得到下述结论。“统一”表示概率至少 $1-\delta$ 的事件中，空间内全部函数同时满足。

**定理 9.9　有限样本的领域自适应期望风险界**　设 $(X, \mathcal{X})$ 为可测输入空间，$Y = \{0,1\}$，$\mathcal{P}_S, \mathcal{P}_T$ 为 $X \times Y$ 上的概率分布，输入边缘分别为 $\mathcal{P}_S^X, \mathcal{P}_T^X$。令 $\mathcal{H}$ 为非空可测二分类假设空间，并定义

$$R_D(h) = \mathbb{P}_{(x,y)\sim\mathcal{P}_D}\{h(x) \neq y\}, \quad \lambda = \inf_{g\in\mathcal{H}} \big(R_S(g) + R_T(g)\big),$$

$$\mathcal{D}_{\mathcal{H}} = \{x \mapsto \mathbb{I}\{h(x) \neq g(x)\} : h, g \in \mathcal{H}\}.$$

令 $n_S, n_T \geq 1$，$S_S = ((x_i^S, y_i^S))_{i=1}^{n_S} \sim \mathcal{P}_S^{n_S}$ 与 $U_T = (x_i^T)_{i=1}^{n_T} \sim (\mathcal{P}_T^X)^{n_T}$ 相互独立，并定义

$$\widehat{R}_{S_S}(h) = \frac{1}{n_S}\sum_{i=1}^{n_S} \mathbb{I}\{h(x_i^S) \neq y_i^S\},$$

$$\widehat{d} = 2 \sup_{h,g\in\mathcal{H}} \left| \frac{1}{n_S}\sum_{i=1}^{n_S} \mathbb{I}\{h(x_i^S) \neq g(x_i^S)\} - \frac{1}{n_T}\sum_{i=1}^{n_T} \mathbb{I}\{h(x_i^T) \neq g(x_i^T)\} \right|.$$

设 $c_{\mathcal{H}}$ 与 $c_{\mathcal{D}}$ 满足：对任意 $\eta \in (0,1)$，

$$\mathbb{P}\left\{ \sup_{h\in\mathcal{H}} |R_S(h) - \widehat{R}_{S_S}(h)| \leq c_{\mathcal{H}}(n_S, \eta) \right\} \geq 1 - \eta,$$

且对 $D \in \{S, T\}$、$m \geq 1$ 及 $V_D = (v_1, \dots, v_m) \sim (\mathcal{P}_D^X)^m$，

$$\mathbb{P}\left\{ \sup_{q \in \mathcal{D}_{\mathcal{H}}} \left| \mathbb{E}_{x \sim \mathcal{P}_D^X} q(x) - \frac{1}{m} \sum_{i=1}^{m} q(v_i) \right| \leq c_{\mathcal{D}}(m, \eta) \right\} \geq 1 - \eta.$$

假设这些上确界均为可测随机变量。则对任意 $\delta \in (0,1)$，以概率至少 $1-\delta$，对全部 $h \in \mathcal{H}$ 同时成立

$$\begin{aligned} R_T(h) \leq \widehat{R}_{S_S}(h) + \tfrac{1}{2}\widehat{d} + \lambda \\ + c_{\mathcal{H}}(n_S, \delta/3) + c_{\mathcal{D}}(n_S, \delta/3) + c_{\mathcal{D}}(n_T, \delta/3). \end{aligned} \tag{9.5}$$

**证明** 分别对源域分类损失、源域分歧函数和目标域分歧函数应用一致收敛保证。三项保证中至少一项失败的概率不超过 $\delta/3 + \delta/3 + \delta/3 = \delta$，这里不要求三项事件独立。在三项均成立时，对每对 $h, g$，两域真实分歧概率之差与经验分歧频率之差的偏差不超过两个 $c_{\mathcal{D}}$ 之和。取上确界后，有

$$\tfrac{1}{2} d_{\mathcal{H}\triangle\mathcal{H}} \leq \tfrac{1}{2}\widehat{d} + c_{\mathcal{D}}(n_S, \delta/3) + c_{\mathcal{D}}(n_T, \delta/3).$$

再用 $R_S(h) \leq \widehat{R}_{S_S}(h) + c_{\mathcal{H}}(n_S, \delta/3)$ 代入总体期望风险界即可。 ■

有限 VC 维控制了三项抽样误差。若 $\mathrm{VC}(\mathcal{H}) = d < \infty$，分类模式受生长函数限制，分歧由两个假设组成，$m$ 点上的模式至多 $\Pi_{\mathcal{H}}(m)^2$。据式 (5.13)，$1 \leq d \leq n$ 时两类 $c$ 皆可取

$$O\left( \sqrt{\frac{d \log(2en/d) + \log(1/\delta)}{n}} \right).$$

将每项控制到 $\varepsilon$ 的充分样本量为 $O((d\log(1/\varepsilon) + \log(1/\delta))/\varepsilon^2)$。目标无标签数据在此估计散度，不能估计 $\lambda$。

参数数量可间接经 VC 维进入抽样代价。$d_{\text{in}}$ 维仿射分类的 VC 维是 $d_{\text{in}} + 1$；满足第 8章条件的 ReLU 网络可用 $d = O(p_{\text{net}} L_{\text{net}} \log p_{\text{net}})$ 上界代入。减少参数有助于减小这一估计项，却不会自动减少共同错误 $\lambda$。有限样本项全部消失后，跨域差异仍在，所以式 (9.5)仍是条件风险界，尚非整个分布族的 PAC 刻画。

**覆盖条件下的加权经验风险** 式 (9.4)的加权恒等式提供另一种情况：已知且统一有界的密度比，让我们从源数据同时估计所有有限候选的目标风险，再用经验最小化控制目标超额风险。

**定理 9.10　已知密度比下的迁移样本量界**　设 $(X,\mathcal{X})$ 与 $(Y,\mathcal{Y})$ 为可测空间，$\mathcal{P}_S,\mathcal{P}_T$ 为 $X\times Y$ 上的概率分布。假设存在共同的条件标签核 $\mathrm{K}(\mathrm{d}y\mid x)$，使 $\mathcal{P}_D(\mathrm{d}x,\mathrm{d}y)=\mathcal{P}_D^X(\mathrm{d}x)\mathrm{K}(\mathrm{d}y\mid x)$ 对 $D\in\{S,T\}$ 成立；并且 $\mathcal{P}_T^X\ll\mathcal{P}_S^X$，已知密度比 $w=\mathrm{d}\mathcal{P}_T^X/\mathrm{d}\mathcal{P}_S^X$ 满足 $0\le w(x)\le\kappa$ 几乎处处成立。令 $\mathcal{H}$ 为含 $1\le N<\infty$ 个可测映射 $h:X\to Y$ 的空间，$\ell:Y\times Y\to[0,1]$ 为可测损失。对 $S=((x_1,y_1),\dots,(x_n,y_n))\sim\mathcal{P}_S^n$，定义

$$R_T(h)=\mathbb{E}_{(x,y)\sim\mathcal{P}_T}\ell(h(x),y),\qquad R_{T,\mathcal{H}}^{\star}=\inf_{h\in\mathcal{H}}R_T(h).$$

给定 $n\ge1$ 个独立源域样本，令

$$\hat{R}_w(h)=\frac{1}{n}\sum_{i=1}^{n}w(x_i)\ell(h(x_i),y_i),\qquad \widehat{h}\in\arg\min_{h\in\mathcal{H}}\hat{R}_w(h).$$

对任意 $\delta,\varepsilon\in(0,1)$，以概率至少 $1-\delta$，

$$R_T(\widehat{h})-R_{T,\mathcal{H}}^{\star}\le\kappa\sqrt{\frac{2\log(2N/\delta)}{n}}.\tag{9.6}$$

特别地，若 $n\ge2\kappa^2\log(2N/\delta)/\varepsilon^2$，则目标域超额期望风险以概率至少 $1-\delta$ 不超过 $\varepsilon$。

**证明**　对每个固定假设，$w(x_i)\ell(h(x_i),y_i)$ 取值在 $[0,\kappa]$，其期望由式 (9.4)给出。Hoeffding 不等式与有限假设空间的概率求和保证，以概率至少 $1-\delta$，全部假设同时满足

$$|R_T(h)-\hat{R}_w(h)|\le a_n,\qquad a_n=\kappa\sqrt{\frac{\log(2N/\delta)}{2n}}.$$

取目标域期望风险最小的 $h^\star\in\mathcal{H}$，由经验最优性有

$$R_T(\widehat{h})\le\hat{R}_w(\widehat{h})+a_n\le\hat{R}_w(h^\star)+a_n\le R_T(h^\star)+2a_n.$$

代入 $a_n$ 得到结论。 ■

定理覆盖共享标签机制、已知密度比和统一 $\kappa$ 的分布族。在此族上，有限假设空间可达到任意目标超额风险精度，因为加权风险能被源数据一致估计。经验最小化给出算法存在性，$\kappa^2$ 样本量只是充分依赖，没有声称最优。

比值未知时，还要证明可从两域输入估计它，这不能由有限 VC 维代替。例如用独立辅助数据构造 $0 \le \widehat{w} \le \kappa$，条件于辅助样本记

$$b_w = \mathbb{E}_{x\sim\mathcal{P}_S^X} |\widehat{w}(x) - w(x)|.$$

损失有界使每个 $h$ 都满足 $|\mathbb{E}_{(x,y)\sim\mathcal{P}_S}[\widehat{w}(x)\ell(h(x),y)] - R_T(h)| \le b_w$。若辅助数据以概率至少 $1-\delta_w$ 保证 $b_w \le \varepsilon_w$，再对独立源标签样本使用上述证明，目标超额风险增加 $2\varepsilon_w$。条件抽样失败概率为 $\delta_\ell$ 时，总失败至多 $\delta_w + \delta_\ell$。只有比值误差在允许族上一致趋零，才保留 PAC 保证。

共享标签核也不能只作为近似口号。若条件标签改变，记

$$b_{\mathrm{cond}} = \mathbb{E}_{x\sim\mathcal{P}_T^X} \mathrm{TV}\big(\mathcal{P}_S(\cdot \mid x), \mathcal{P}_T(\cdot \mid x)\big),$$

总变差表示两分布对同一事件赋概率的最大差。$[0,1]$ 损失使式 (9.4)两端误差至多 $b_{\mathrm{cond}}$，超额风险界便增加 $2b_{\mathrm{cond}}$。固定正残余只能支持近似保证，不能达到任意小精度。

标签偏移要识别类别比例。若源两类条件输入分布相同，不同目标比例会产生相同无标签分布，便不可识别。对 $Y = \{1,\dots,C\}$，先要求源各类有正概率，记共同类条件分布 $\mathsf{K}_y = \mathcal{P}_S^X(\cdot \mid y)$ 和目标比例 $q_y = \mathcal{P}_T^Y(\{y\})$，则

$$\mathcal{P}_T^X = \sum_{y=1}^{C} q_y \mathsf{K}_y, \qquad q_y \ge 0, \qquad \sum_{y=1}^{C} q_y = 1.$$

目标输入须属于这些分布的凸包,且凸组合唯一才有点识别。若 $\sum_{y=1}^{C} a_y \mathsf{K}_y = 0$ 仅在全部 $a_y = 0$ 时成立，就能保证唯一性。

唯一性还须配合有限样本条件数。选有界统计向量 $\boldsymbol{\psi} : X \to \mathbb{R}^m$、$\|\boldsymbol{\psi}(x)\|_2 \le B_\psi$，矩阵 $\boldsymbol{M} \in \mathbb{R}^{m\times C}$ 第 $y$ 列为 $\mathbb{E}_{x\sim\mathsf{K}_y}\boldsymbol{\psi}(x)$。记 $\boldsymbol{q} = (q_1,\dots,q_C)^\top$，则目标统计满足 $\mathbb{E}_{x\sim\mathcal{P}_T^X}\boldsymbol{\psi}(x) = \boldsymbol{M}\boldsymbol{q}$。若 $\boldsymbol{M}$ 满列秩、允许族上 $\sigma_{\min}(\boldsymbol{M}) \ge c > 0$，且源类别概率对 $y = 1,\dots,C$ 统一满足 $\mathcal{P}_S^Y(\{y\}) \ge \pi_{\min} > 0$，统计估计误差才可统一转为比例误差。$c$ 或 $\pi_{\min}$ 趋零会任意放大误差。因此各偏移类型需要自己的识别与稳定估计条件，不能共用参数数目判据。

**参数范数与加权 Rademacher 复杂度** 高维模型的 VC 界可能较大，范数约束却能限制较小函数空间。第 8章用 Rademacher 复杂度说明了这点。迁移中保留相同范数条件，还须计算重加权怎样放大样本复杂度。

在已知比值设定中，取 $f_\theta(\boldsymbol{x}) = \langle\theta,\boldsymbol{x}\rangle$，$\|\theta\|_2 \le B$、$\|\boldsymbol{x}\|_2 \le r$。损失取值 $[0,1]$，对预测为 $L_\ell$-Lipschitz，即分数改变 $a$ 最多改变 $L_\ell|a|$ 损失。范数限制分数变化，密度比则分配源输入对目标评价的贡献，二者将一起进入复杂度。

**定理 9.11　范数受限线性预测的迁移保证**　设 $n, p \geq 1$，$X \subseteq \mathbb{R}^p$ 取 Borel $\sigma$ 代数，$(Y, \mathcal{Y})$ 为可测标签空间，$\mathcal{P}_S, \mathcal{P}_T$ 为 $X \times Y$ 上的概率分布。假设两域共享条件标签核 $\mathsf{K}(\mathrm{d}y \mid \boldsymbol{x})$，即 $\mathcal{P}_D(\mathrm{d}\boldsymbol{x}, \mathrm{d}y) = \mathcal{P}_D^X(\mathrm{d}\boldsymbol{x})\mathsf{K}(\mathrm{d}y \mid \boldsymbol{x})$ 对 $D \in \{S, T\}$ 成立，且 $\mathcal{P}_T^X \ll \mathcal{P}_S^X$ 的已知密度比 $w = \mathrm{d}\mathcal{P}_T^X / \mathrm{d}\mathcal{P}_S^X$ 满足 $0 \leq w(\boldsymbol{x}) \leq \kappa$ 几乎处处成立。对 $\|\boldsymbol{\theta}\|_2 \leq B$，令 $f_{\boldsymbol{\theta}}(\boldsymbol{x}) = \langle \boldsymbol{\theta}, \boldsymbol{x} \rangle$。假设 $\|\boldsymbol{x}\|_2 \leq r$ 在 $\mathcal{P}_S^X$ 下几乎处处成立，损失 $\ell : \mathbb{R} \times Y \to [0, 1]$ 可测，且关于第一个变量为 $L_\ell$-Lipschitz。定义

$$R_T(f_{\boldsymbol{\theta}}) = \mathbb{E}_{(\boldsymbol{x}, y) \sim \mathcal{P}_T} \ell(f_{\boldsymbol{\theta}}(\boldsymbol{x}), y).$$

对 $S = ((\boldsymbol{x}_1, y_1), \ldots, (\boldsymbol{x}_n, y_n)) \sim \mathcal{P}_S^n$，令

$$\hat{R}_w(\boldsymbol{\theta}) = \frac{1}{n} \sum_{i=1}^{n} w(\boldsymbol{x}_i) \ell(f_{\boldsymbol{\theta}}(\boldsymbol{x}_i), y_i), \qquad \widehat{\boldsymbol{\theta}} \in \operatorname*{arg\,min}_{\|\boldsymbol{\theta}\|_2 \leq B} \hat{R}_w(\boldsymbol{\theta}).$$

固定 $B, r, L_\ell, \kappa > 0$。对任意 $\delta, \varepsilon \in (0, 1)$，以概率至少 $1 - \delta$，

$$R_T(f_{\widehat{\boldsymbol{\theta}}}) - \inf_{\|\boldsymbol{\theta}\|_2 \leq B} R_T(f_{\boldsymbol{\theta}}) \leq \frac{4\kappa L_\ell B r}{\sqrt{n}} + 6\kappa \sqrt{\frac{\log(4/\delta)}{2n}}. \tag{9.7}$$

因此，存在普适常数 $C$，当 $n \geq C\kappa^2((L_\ell B r)^2 + \log(4/\delta))/\varepsilon^2$ 时，目标域超额期望风险以概率至少 $1 - \delta$ 不超过 $\varepsilon$。

**证明**　记 $\mathcal{F}_w$ 为加权损失函数空间。固定源域样本后，令 $w_i = w(x_i)$，$\sigma_i$ 为相互独立的随机正负号。由 Lipschitz 收缩性质与欧氏范数的对偶关系，

$$\begin{aligned} \widehat{\mathfrak{R}}_S(\mathcal{F}_w) &\leq \frac{L_\ell B}{n} \mathbb{E}_{\boldsymbol{\sigma}} \left\| \sum_{i=1}^{n} \sigma_i w_i \boldsymbol{x}_i \right\|_2 \\ &\leq \frac{L_\ell B}{n} \sqrt{\sum_{i=1}^{n} w_i^2 \|\boldsymbol{x}_i\|_2^2} \leq \frac{\kappa L_\ell B r}{\sqrt{n}}. \end{aligned}$$

第二步使用 Cauchy–Schwarz 不等式；展开范数平方后，不同随机正负号的交叉项期望为零。收缩时可先减去每个样本上的 $w_i \ell(0, y_i)$，这些与参数无关的项不改变 Rademacher 复杂度。

对加权损失 $f \in \mathcal{F}_w$ 及其补函数 $\kappa - f$，分别应用基于经验 Rademacher 复杂度的期望风险界。两者都取值于 $[0, \kappa]$；各分配 $\delta/2$

的失败概率，便能同时控制期望风险高于和低于经验风险的偏差，得到

$$\sup_{\|\theta\|_2 \le B} |R_T(f_\theta) - \hat{R}_w(f_\theta)| \le \frac{2\kappa L_\ell B r}{\sqrt{n}} + 3\kappa\sqrt{\frac{\log(4/\delta)}{2n}}.$$

经验最小化的目标域超额期望风险不超过这个统一偏差的两倍，证明完成。 ■

此处使用 $B, r, L_\ell$ 而未显含参数维度 $p$，但只有它们不随 $p$ 增长时才消除直接维度依赖。例如固定每坐标尺度会使 $r$ 随 $\sqrt{p}$ 增长，仍增加样本量。$\kappa$ 增大同样增加源样本需求，反映目标重要区域在源中稀少的代价。

零一损失不连续，不能直接满足该 Lipschitz 条件。分类可用第 8章的间隔损失，取 $L_\ell = 1/\gamma$，以目标间隔损失上界控制分类风险；得到的保证保留间隔要求，并非全部零一分类器的不可知 PAC 刻画。深网络也可先以各层谱范数估计损失复杂度，再通过相同跨域关系转换。一般损失与分布差异的分析见 Mansour 等[3]。

### 9.2.3 基于输出的有限样本保证

前面的统一偏差覆盖所有候选，允许最终假设由数据选择。现在改为分析实际输出：稳定性比较换样本后的输出，PAC–Bayes 评价完整随机预测器。两条路径都还需跨域关系与经验拟合，只补充有限样本控制。

**算法稳定性与可学习性** 小范数限制候选函数，但不直接限制替换样本后的输出变化；稳定输出也可能始终选错固定假设。要沿算法路线证明学习，我们分别估计输出的样本敏感度和经验优化误差。

在已知密度比的协变量偏移下，可以直接将第 7章的稳定性用于加权损失。若替换源样本后任意观测损失的内部随机性期望改变至多 $\beta_n$，乘上 $w(x) \le \kappa$ 后，加权稳定性至多 $\kappa\beta_n$。这里平均的是算法随机性，样本和测试观测仍由均匀量词控制。

**定理 9.12 稳定性条件下的迁移可学习性** 设 $(X, \mathcal{X})$ 与 $(Y, \mathcal{Y})$ 为可测空间，$\mathcal{P}_S, \mathcal{P}_T$ 为 $X \times Y$ 上的概率分布。假设两域共享条件标签核 $\mathrm{K}(\mathrm{d}y \mid x)$，即 $\mathcal{P}_D(\mathrm{d}x, \mathrm{d}y) = \mathcal{P}_D^X(\mathrm{d}x)\mathrm{K}(\mathrm{d}y \mid x)$ 对 $D \in \{S, T\}$ 成立，且 $\mathcal{P}_T^X \ll \mathcal{P}_S^X$ 的已知密度比 $w = \mathrm{d}\mathcal{P}_T^X / \mathrm{d}\mathcal{P}_S^X$ 满足 $0 \le w(x) \le \kappa$ 几乎处处成立。令 $\mathcal{H}$ 为由可测映射 $h : X \to Y$ 组成的假设空间，$\ell : Y \times Y \to [0, 1]$ 为可测损失，并定义

$$R_T(h) = \mathbb{E}_{(x,y)\sim\mathcal{P}_T}\ell(h(x), y), \qquad R_{T,\mathcal{H}}^\star = \inf_{h\in\mathcal{H}} R_T(h).$$

令 $S=(z_1,\dots,z_n)\sim \mathcal{P}_S^n$，其中 $z_i=(x_i,y_i)$，并定义

$$\hat{R}_w(h)=\frac{1}{n}\sum_{i=1}^{n} w(x_i)\ell(h(x_i),y_i).$$

可能随机化的算法 $A$ 输出 $\mathcal{H}$ 中的假设。假设对任意相邻源域样本 $S,S'$ 和任意 $z=(x,y)\in X\times Y$ 都有

$$\left|\mathbb{E}_A\ell(A(S)(x),y)-\mathbb{E}_A\ell(A(S')(x),y)\right|\le\beta_n,$$

其中 $\mathbb{E}_A$ 只对算法内部随机性取期望，并且

$$\mathbb{E}\left[\hat{R}_w(A(S))-\inf_{h\in\mathcal{H}}\hat{R}_w(h)\right]\le\rho_n.$$

其中 $n\ge 1$ 且 $\kappa,\beta_n,\rho_n\ge 0$。则

$$\mathbb{E}[R_T(A(S))-R^{\star}_{T,\mathcal{H}}]\le\kappa\beta_n+\rho_n. \tag{9.8}$$

若 $\kappa\beta_n+\rho_n$ 在允许的分布族上一致趋于零，则该设定 PAC 可学习。具体地，对任意 $\varepsilon,\delta\in(0,1)$，使 $\kappa\beta_n+\rho_n\le\varepsilon\delta$，便足以保证目标域超额期望风险以概率至少 $1-\delta$ 不超过 $\varepsilon$。

**证明**　加权损失的均匀稳定性与式 (9.4)给出

$$\mathbb{E}[R_T(A(S))-\hat{R}_w(A(S))]\le\kappa\beta_n.$$

对任意固定 $h\in\mathcal{H}$，又有

$$\mathbb{E}\inf_{g\in\mathcal{H}}\hat{R}_w(g)\le\mathbb{E}\hat{R}_w(h)=R_T(h).$$

将目标域超额期望风险分解为期望风险与经验风险之差、经验优化误差以及最优经验风险与最优目标域期望风险之差，合并上述不等式并对 $h$ 取下确界，得到期望结论。由于 $A(S)\in\mathcal{H}$，目标域超额期望风险非负，对它使用 Markov 不等式即可得到所述概率保证。 ■

右侧 $\kappa\beta_n$ 估计目标风险与加权经验评价的平均差，$\rho_n$ 估计加权经验优化误差。若 $\beta_n\le c/n$、$\rho_n\le a/n$，取 $n\ge(\kappa c+a)/(\varepsilon\delta)$ 便达到充分要求。这条 Markov 推导没有优化置信度依赖，但明确说明了两项怎样共同支持迁移。

若损失对参数为 $G$-Lipschitz，相邻源样本输出的期望距离至多 $s_n$，便有 $\beta_n\le Gs_n$，式 (9.8)变为 $\kappa Gs_n+\rho_n$。使用正则化或 SGD 参数界时，要确

认算法优化的是当前加权目标，并检查相应光滑、凸等条件。共享标签和覆盖仍是转换到目标风险的前提，参数不变也无法补出隐藏目标标签。

**参数分布与 PAC–Bayes** 对随机训练或预测，还可评价参数分布的选择代价。第 8章的 PAC–Bayes 控制源域总体与经验风险之间的差。跨到目标后，这项仍只处理源抽样误差，另外要比较两域预测分歧与共同错误。

取二分类零一损失，后验为 $Q$。Gibbs 预测每次抽一个 $h \sim Q$，域 $D$ 风险为 $r_D(Q) = \mathbb{E}_{h\sim Q} R_D(h)$。再独立抽 $h, g$，分别定义预测分歧与共同错误：

$$d_D(Q) = \mathbb{E}_{h,g\sim Q} \mathbb{P}_{x\sim \mathcal{P}_D^X}(h(x) \neq g(x)),$$
$$e_D(Q) = \mathbb{E}_{h,g\sim Q} \mathbb{P}_{(x,y)\sim \mathcal{P}_D}(h(x) \neq y,\ g(x) \neq y).$$

第一项只需输入，第二项需要标签。这使参数分布路线也保留可见信息的边界。

**定理 9.13 参数分布的跨域期望风险界** 设 $(X, \mathcal{X})$ 为可测输入空间，$Y = \{0, 1\}$，$\mathcal{P}_S, \mathcal{P}_T$ 为 $X \times Y$ 上的概率分布，$\mathcal{H}$ 为由可测二分类假设组成并带有相应 $\sigma$ 代数的空间。对 $D \in \{S, T\}$，定义零一风险

$$R_D(h) = \mathbb{P}_{(x,y)\sim \mathcal{P}_D}\{h(x) \neq y\}.$$

对 $\mathcal{H}$ 上的概率分布 $Q$，独立抽取 $h, g \sim Q$，并定义

$$r_D(Q) = \mathbb{E}_{h\sim Q} R_D(h),$$
$$d_D(Q) = \mathbb{E}_{h,g\sim Q} \mathbb{P}_{x\sim \mathcal{P}_D^X}\{h(x) \neq g(x)\},$$
$$e_D(Q) = \mathbb{E}_{h,g\sim Q} \mathbb{P}_{(x,y)\sim \mathcal{P}_D}\{h(x) \neq y,\ g(x) \neq y\}.$$

设 $n \geq 1$，$S_S = ((x_1, y_1), \ldots, (x_n, y_n)) \sim \mathcal{P}_S^n$，并令

$$\widehat{r}_{S_S}(Q) = \mathbb{E}_{h\sim Q}\left[\frac{1}{n}\sum_{i=1}^{n} \mathbb{I}\{h(x_i) \neq y_i\}\right].$$

设 $P_0$ 为 $\mathcal{H}$ 上的先验分布，且与 $S_S$ 独立。对任意 $\delta \in (0, 1)$，以概率至少 $1 - \delta$，对所有 $Q \ll P_0$ 同时有

$$r_T(Q) \leq \widehat{r}_{S_S}(Q) + \sqrt{\frac{D_{\mathrm{KL}}(Q\|P_0) + \log((n+1)/\delta)}{2n}} + \frac{1}{2}|d_T(Q) - d_S(Q)| + |e_T(Q) - e_S(Q)|, \tag{9.9}$$

**证明** 固定 $(x,y)$，令 $p=\mathbb{P}_{h\sim Q}(h(x)\neq y)$。两个独立抽取的二分类假设分歧的概率为 $2p(1-p)$，同时错误的概率为 $p^2$。等式 $p=\frac{1}{2}\cdot 2p(1-p)+p^2$ 在域 $D$ 上取期望后给出

$$r_D(Q)=\tfrac{1}{2}d_D(Q)+e_D(Q).$$

分别代入 $D=T,S$ 并相减，可得

$$r_T(Q)\le r_S(Q)+\tfrac{1}{2}|d_T(Q)-d_S(Q)|+|e_T(Q)-e_S(Q)|.$$

对 $r_S(Q)$ 应用定理 8.19的 PAC–Bayes 上界，得到结论。 ■

分解采用 Germain 等的分析[4]。平方根项来自源抽样，其余两项比较同一后验在两域的分歧和共同错误。增加源样本直接降低前项，但若目标共同错误差无结构控制，无标签目标数据仍不能使全部代价任意小。

[4] P. Germain, A. Habrard, F. Laviolette, E. Morvant, *An Improvement to the Domain Adaptation Bound in a PAC-Bayesian Context* In arXiv preprint arXiv:1501.03002, 2015

相同协方差的高斯先验与后验给出参数位移的具体入口。取 $\mathbb{R}^p$ 上的协方差 $\sigma^2\boldsymbol{I}_p$，均值 $\boldsymbol{\mu}_0,\boldsymbol{\mu}$，则

$$D_{\mathrm{KL}}(Q\|P_0)=\frac{\|\boldsymbol{\mu}-\boldsymbol{\mu}_0\|_2^2}{2\sigma^2}.$$

缩小位移会降低代价，增大 $\sigma$ 也降低此式，却改变随机预测并可能增加经验风险。若源经验风险与跨域残余已足够小，且有样本无关的统一上界 $D_{\mathrm{KL}}(Q\|P_0)\le B_{\mathrm{KL}}$，$n\ge[B_{\mathrm{KL}}+\log((n+1)/\delta)]/(2\varepsilon^2)$ 足以将复杂度项降到 $\varepsilon$。这是充分条件，不是算法样本下界；数据选择的 $Q$ 可得到事后证书，预定门槛则还需 KL 统一控制。

预训练模型也可构造先验，但须独立于本次计算经验风险的源样本；否则需采用允许数据依赖先验的相应理论。

当前保证直接评价 Gibbs 预测，不自动评价后验均值网络。PAC–Bayes 比较分布与先验，稳定性比较相邻样本输出，分别补充算法信息。迁移中二者仍须跨域标签联系，参数复杂度无法代替未观察标签。

### 9.2.4 理论比较与适用边界

各路线先固定不同跨域关系。分歧界组合源风险、输入散度与共同错误；重加权保留标签核和覆盖；后验分解比较 Gibbs 分歧与共同错误。复杂度项形式相近，并不让这些分布假设等价。

固定跨域关系后，VC 维、Rademacher 与范数控制候选空间的估计，稳定性控制实际算法响应，PAC–Bayes 控制相对先验的分布选择。候选复杂度小不蕴含稳定，稳定不蕴含经验最优，Gibbs 风险也不等于均值参数风险。每条保证要保留自己的输出与比较条件。

即使抽样代价趋零，$\lambda$、比值误差、标签变化或共同错误差若仍为正，就未必能达到任意目标精度。因此 PAC 结论必须同时列明允许分布族、可见信息、跨域残余与有限样本条件。

## 9.3 领域泛化的可学习性

领域泛化取消了自适应可用的目标输入。若允许任意新环境，定理 9.3的不可识别反例仍成立。要得到保证，我们必须限制训练与未来环境的联系，并明确评价哪一种新环境风险。

一条路径要求每个允许目标保留共同标签机制，且受训练混合输入覆盖；另一条路径假定训练与未来环境从共同总体抽样，评价未来随机环境的平均。它们改变的是外层评价对象，下面分别建立。

### 9.3.1 逐目标域保证

多个训练域可以联合覆盖目标输入。令 $\mathcal{P}_1, \dots, \mathcal{P}_K$ 为源分布，混合 $\overline{\mathcal{P}} = K^{-1} \sum_{e=1}^{K} \mathcal{P}_e$。每次等概率选域再抽观测，就得到混合分布样本。若目标重要输入在混合中有足够概率，便可利用训练域标签；还须下面的共享机制条件。

对二分类，假设训练域和允许目标均共享 $\eta(x) = \mathbb{P}(y = 1 \mid x)$，并有 $h^\star(x) = \mathbb{I}\{\eta(x) \geq 1/2\} \in \mathcal{H}$。这一假设规定未来标签规律，不只是训练域恰好共享一个经验最优者，因此比训练拟合的共同性更强。

相对共同贝叶斯分类器，在 $h(x) = h^\star(x)$ 的输入处没有额外错误，预测不同则多出 $|2\eta(x) - 1|$ 的条件错误。因此每个共享机制的域满足

$$R_D(h) - R_D(h^\star) = \mathbb{E}_{x \sim \mathcal{P}_D^X}[|2\eta(x) - 1| \mathbb{I}\{h(x) \neq h^\star(x)\}]. \tag{9.10}$$

积分函数在两域相同且非负，覆盖就能把源混合上的超额风险转为目标超额风险。非负性是这一方向不等式的依据。

**定理 9.14　共享标签机制下的领域泛化**　设 $(X, \mathcal{X})$ 为可测输入空间，$Y = \{0, 1\}$。给定 $K \geq 1$ 个训练域分布 $\mathcal{P}_1, \dots, \mathcal{P}_K$ 及非空的允许目标域集合 $\mathcal{T}$，它们均为 $X \times Y$ 上的概率分布。令 $\overline{\mathcal{P}} = K^{-1} \sum_{e=1}^{K} \mathcal{P}_e$。假设存在同一个可测函数 $\eta : X \to [0, 1]$，使每个训练域及每个 $\mathcal{P}_T \in \mathcal{T}$ 的条件标签分布都满足 $\mathbb{P}(y = 1 \mid x) = \eta(x)$；令 $h^\star(x) = \mathbb{I}\{\eta(x) \geq 1/2\}$。设 $\mathcal{H}$ 为含 $N < \infty$ 个可测二分类假设的空间，且 $h^\star \in \mathcal{H}$。对任意域 $D$ 定

义零一风险 $R_D(h)=\mathbb{P}_{(x,y)\sim\mathcal{P}_D}\{h(x)\neq y\}$，并令 $R^\star_{T,\mathcal{H}}=\inf_{h\in\mathcal{H}}R_T(h)$。若对每个 $\mathcal{P}_T\in\mathcal{T}$ 与每个可测输入集合 $B$ 都有

$$\mathcal{P}_T^X(B)\le\kappa\overline{\mathcal{P}}^X(B),$$

其中 $\kappa>0$，则从 $\overline{\mathcal{P}}$ 独立抽取 $S=(z_1,\dots,z_m)\sim\overline{\mathcal{P}}^m$，并令

$$\widehat{h}\in\arg\min_{h\in\mathcal{H}}\frac{1}{m}\sum_{i=1}^{m}\mathbb{I}\{h(x_i)\neq y_i\}.$$

对任意 $m\ge 1$ 和 $\delta,\varepsilon\in(0,1)$，以概率至少 $1-\delta$，对全部 $\mathcal{P}_T\in\mathcal{T}$ 同时有

$$R_T(\widehat{h})-R^\star_{T,\mathcal{H}}\le\kappa\sqrt{\frac{2\log(2N/\delta)}{m}}. \tag{9.11}$$

故 $m\ge 2\kappa^2\log(2N/\delta)/\varepsilon^2$ 是保证目标域超额期望风险不超过 $\varepsilon$ 的充分样本量条件。

若进一步有 $\eta(x)\in\{0,1\}$ 在 $\overline{\mathcal{P}}^X$ 下几乎处处成立，则任意与样本一致的假设都满足可实现 PAC 保证，只需

$$m\ge\frac{\kappa}{\varepsilon}\bigl(\log N+\log(1/\delta)\bigr).$$

**证明**　由式 (9.10)与覆盖条件，对任意 $h\in\mathcal{H}$，

$$R_T(h)-R_T(h^\star)\le\kappa\bigl(R_{\overline{\mathcal{P}}}(h)-R_{\overline{\mathcal{P}}}(h^\star)\bigr).$$

$h^\star$ 在混合分布及各目标域中都是 $\mathcal{H}$ 内最优假设。有限假设空间的不可知 PAC 样本量界给出

$$R_{\overline{\mathcal{P}}}(\widehat{h})-R_{\overline{\mathcal{P}}}(h^\star)\le\sqrt{\frac{2\log(2N/\delta)}{m}}.$$

控制混合分布超额期望风险的同一个事件适用于全部目标域，因此得到同时保证。

在可实现情形，$R_D(h^\star)=0$。若某个假设在某个允许目标域上的期望风险大于 $\varepsilon$，则它在混合分布上的期望风险必大于 $\varepsilon/\kappa$。这样的固定假设与 $m$ 个样本一致的概率至多为 $\exp(-m\varepsilon/\kappa)$。对至多 $N$ 个假设的失败概率求和，再令结果不超过 $\delta$，得到第二个样本量条件。 ■

这个结论在同一训练事件中覆盖全部允许目标，比定义 9.5逐域要求更强。算法只学习共享分类器，不需要目标样本或目标密度比；覆盖限制了

源错误向目标的放大。抽样必须是每次独立选域再取观测，固定每域数量的分层样本需另证，不能直接当混合独立样本。

无限空间可用复杂度替代有限计数。若混合分布上的统一偏差至多 $c_{\mathcal{H}}(m,\delta)$，相同证明得到目标超额风险至多 $2\kappa c_{\mathcal{H}}(m,\delta)$。有限 VC 维给出充分路径，范数与合适损失的 Rademacher 界也可控制源估计。一般损失的跨域转换还需证明式 (9.10)类似的非负条件超额关系。

若已知 $\Phi(x)$ 保留共同标签核，可在表示空间固定共享机制与覆盖，再分析 $h\circ\Phi$。若 $\Phi$ 也从数据学习，还需识别它并控制组合空间复杂度。有限训练域上同一预测头最优，尚未证明未来也最优。不变风险最小化提出寻找共同最优预测关系的思路[5]。

训练环境必须提供足够变化来识别不变关系；否则偶然相关特征也可能在全部已见域稳定，在目标失效。IRM 风险分析展示了这类边界[6]。所以允许环境、表示识别与假设空间仍需明确，训练约束不能替代未来分布条件。

[5] M. Arjovsky, L. Bottou, I. Gulrajani, D. Lopez-Paz, *Invariant Risk Minimization* In arXiv preprint arXiv:1907.02893, 2019

[6] E. Rosenfeld, P. Ravikumar, A. Risteski, *The Risks of Invariant Risk Minimization* In International Conference on Learning Representations, 2021

**表示充分性与近似误差** 即使类内风险受控，表示也可能丢失目标信息。固定已学习 $\Phi$，令 $\mathcal{H}_\Phi=\{g\circ\Phi : g\in\mathcal{G}\}$，相对贝叶斯风险有

$$R_T(\widehat{h})-R_T^{\mathrm{Bayes}}=\left[R_T(\widehat{h})-\inf_{h\in\mathcal{H}_\Phi}R_T(h)\right]+\left[\inf_{h\in\mathcal{H}_\Phi}R_T(h)-R_T^{\mathrm{Bayes}}\right]. \tag{9.12}$$

第一项是类内学习差，第二项是表示近似差。小预测头可减少估计，却不能修复被 $\Phi$ 映到同一点的不同类别。表示与头若共同选择，也需控制整体复杂度，不能事后只计算头。因此共享机制、覆盖与复杂度须配合表示充分性。

### 9.3.2 环境平均保证

环境平均换了评价要求，不逐一保证所有目标机制。按定义 9.6，训练与未来环境来自共同总体。例如将用户视为环境，从同一用户总体独立选训练用户和新用户，评价未来用户的平均风险。

令环境总体为 $\mathcal{Q}$，一次抽取给出联合分布 $\mathcal{P}$。先独立抽 $K$ 个 $\mathcal{P}_e$，再每域取 $n$ 个 $z_{e,i}=(x_{e,i},y_{e,i})$；条件于环境，全部观测独立。固定输出 $h$ 的总体与经验评价为

$$R_{\mathcal{Q}}(h)=\mathbb{E}_{\mathcal{P}\sim\mathcal{Q}}R_{\mathcal{P}}(h),\qquad \widehat{R}_{\mathcal{S}}(h)=\frac{1}{Kn}\sum_{e=1}^{K}\sum_{i=1}^{n}\ell(h,z_{e,i}). \tag{9.13}$$

损失仍为 $\ell(h,z)=\ell(h(x),y)$。前者先域内再域间平均，后者用两层抽样估计这个量。

两层抽样形成两种信息量。增大 $n$ 改善已见环境的风险估计，增大 $K$ 增加独立环境信息。固定 $K$ 而无限增加 $n$，仍只观察这些环境。

图 9.6在相同总观测下比较增点与增行。原域内采样只增加行内点，另抽环境增加独立行。$R_Q$ 还平均环境总体，因而二者不能互相替代。

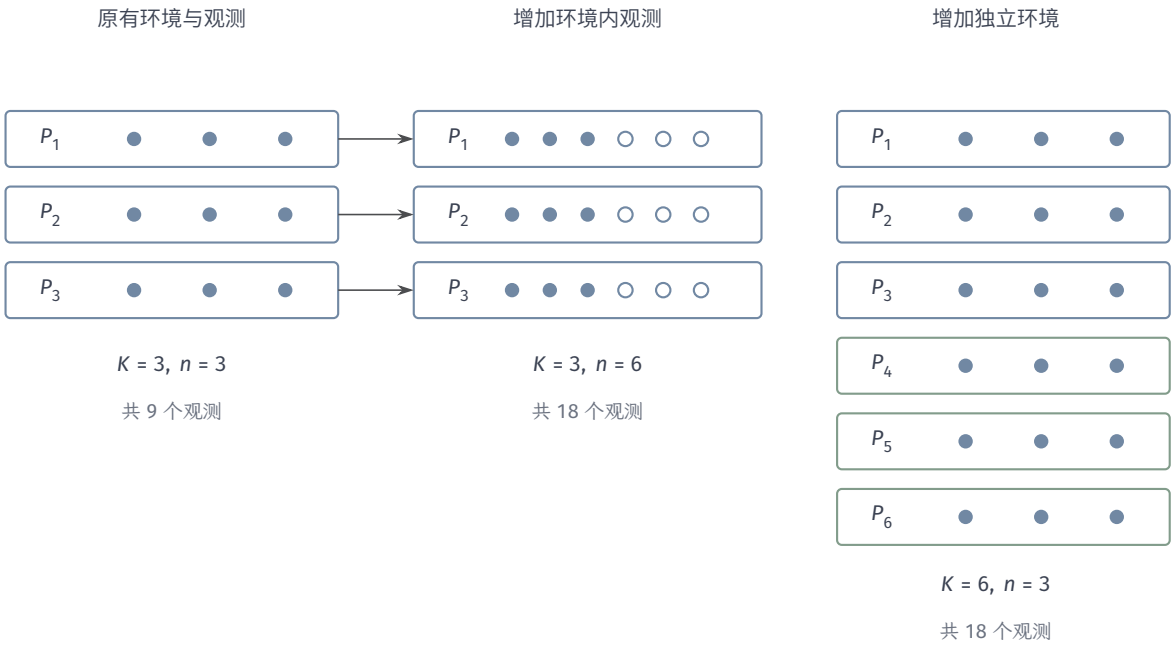


图 9.6　环境数量 $K$ 与环境内样本数 $n$ 对应不同的抽样层。每行边界代表一个环境，圆点代表其中的观测。左侧从同一环境分布 $Q$ 独立抽取 3 个环境，各取 3 个观测；中间的空心点表示在原有 3 个环境中继续抽取的观测，每个环境增至 6 个；右侧从 $Q$ 新抽取 3 个独立环境，每个环境仍取 3 个观测。中、右都有 18 个观测，只有右侧增加了独立环境数量。图中数量为教学构造，不对应实测数据。

**定理 9.15　随机环境中的一致收敛与可学习性**　设 $(Z,\mathcal{Z})$ 为可测观测空间，$Q$ 为定义在 $Z$ 上概率分布所组成空间上的环境分布。令 $\mathcal{H}$ 为含 $1\le N<\infty$ 个假设的空间，$\ell:\mathcal{H}\times Z\to[0,1]$ 可测。先独立抽取 $\mathcal{P}_1,\dots,\mathcal{P}_K\sim Q$；给定这些环境后，对每个 $e$ 独立抽取 $D_e=(z_{e,1},\dots,z_{e,n})\sim\mathcal{P}_e^n$，且不同环境的数据块条件独立。记 $\mathcal{S}=(D_1,\dots,D_K)$，其中 $K,n\ge 1$，并定义

$$R_{\mathcal{P}}(h)=\mathbb{E}_{z\sim\mathcal{P}}\ell(h,z),\qquad R_Q(h)=\mathbb{E}_{\mathcal{P}\sim Q}R_{\mathcal{P}}(h),$$

$$\widehat{R}_{\mathcal{S}}(h)=\frac{1}{Kn}\sum_{e=1}^{K}\sum_{i=1}^{n}\ell(h,z_{e,i}).$$

对任意 $\delta, \varepsilon \in (0,1)$，以概率至少 $1-\delta$，对所有 $h \in \mathcal{H}$ 同时有

$$|R_Q(h) - \widehat{R}_S(h)| \le \sqrt{\frac{\log(4N/\delta)}{2K}} + \sqrt{\frac{\log(4N/\delta)}{2Kn}}. \tag{9.14}$$

令 $\widehat{h} \in \arg\min_{h\in\mathcal{H}} \widehat{R}_S(h)$，则其环境平均超额期望风险 $R_Q(\widehat{h}) - \inf_{h\in\mathcal{H}} R_Q(h)$ 不超过所列右侧的两倍。特别地，若

$$K \ge \frac{8\log(4N/\delta)}{\varepsilon^2}, \qquad Kn \ge \frac{8\log(4N/\delta)}{\varepsilon^2},$$

则

$$\mathbb{P}\left\{R_Q(\widehat{h}) - \inf_{h\in\mathcal{H}} R_Q(h) \le \varepsilon\right\} \ge 1-\delta.$$

**证明** 在真实环境平均期望风险和经验风险之间插入已见环境的期望风险平均值：

$$\begin{aligned}|R_Q(h) - \widehat{R}_S(h)| \le{}& \left|R_Q(h) - \frac{1}{K}\sum_{e=1}^{K} R_{\mathcal{P}_e}(h)\right| \\ &+ \left|\frac{1}{K}\sum_{e=1}^{K} R_{\mathcal{P}_e}(h) - \widehat{R}_S(h)\right|.\end{aligned}$$

第一项包含 $K$ 个独立环境，每个 $R_{\mathcal{P}_e}(h)$ 都在 $[0,1]$ 中。对固定 $h$ 应用 Hoeffding 不等式，再对 $N$ 个假设求和，以失败概率 $\delta/2$ 得到第一项的统一上界。

第二项在给定全部 $\mathcal{P}_e$ 后，是 $Kn$ 个独立、有界但未必同分布的观测相对于各自期望的平均偏差。Hoeffding 不等式仍然适用，再对 $N$ 个假设求和，以条件失败概率 $\delta/2$ 得到第二项上界。该保证对每组环境都成立，因此无条件失败概率也不超过 $\delta/2$。合并两个事件得到一致收敛结论，ERM 的超额期望风险再由两次偏差控制得到。 ■

充分门槛可以写为

$$K \ge \frac{8\log(4N/\delta)}{\varepsilon^2}, \qquad Kn \ge \frac{8\log(4N/\delta)}{\varepsilon^2}.$$

$n \ge 1$ 使第一项蕴含第二项，说明对任意环境总体的这条最坏情形分析可能由环境数量主导。域内数据仍有估计作用，但未进一步限制域差异时，增加已见域观测无法排除未来环境变化。

无限空间要分别控制两层函数：环境层为 $\mathcal{P} \mapsto R_{\mathcal{P}}(h)$，域内为 $z \mapsto \ell(h,z)$。参数、范数或 Rademacher 量须用于实际约束的层。学习共享表

示与任务头时，还要分开表示复杂度、头复杂度和任务数；多任务表示理论由此得到样本量关系[7]。

本定理比较共同假设在环境总体的平均风险，允许某些环境风险高，也不与逐环境最佳选择比较。如果输出能够用目标数据适应，输出对象与基准都须重定，不能继续沿用固定假设结论。

[7] A. Maurer, M. Pontil, B. Romera-Paredes, *The Benefit of Multitask Representation Learning* In Journal of Machine Learning Research, 2016, vol. 17, no. 81, pp. 1–32

**基于环境稳定性的算法保证** 还可把第 7章的稳定性用于环境层：将一整个训练数据块换成另一个环境块，比较实际算法的损失。这样不再同时控制全部候选，而控制所用算法。

记环境块 $D_e = (z_{e,1}, \dots, z_{e,n})$，全部数据为 $S = (D_1, \dots, D_K)$。不条件于环境时，同块观测通常相关，但各块仍独立同分布。对新块定义 $L(h, D) = n^{-1} \sum_{i=1}^{n} \ell(h, z_i)$，其期望为 $R_Q(h)$。因此可以把整块当作稳定性定理中的一个观测单位。

**定义 9.16 环境均匀稳定性** 设 $A$ 接收 $K$ 个环境数据块。若对任意仅在一个数据块上不同的 $S, S'$，以及任意测试观测 $z$，均有

$$\left| \mathbb{E}_A \ell(A(S), z) - \mathbb{E}_A \ell(A(S'), z) \right| \le \gamma_K,$$

则称 $A$ 具有参数为 $\gamma_K$ 的环境均匀稳定性。这里 $\mathbb{E}_A$ 只对算法 $A$ 的内部随机性取期望，$S, S'$ 与 $z$ 均固定。

**定理 9.17 环境稳定性与平均可学习性** 设 $(Z, \mathcal{Z})$ 为可测观测空间，$\mathfrak{M}$ 为环境分布族；每个 $Q \in \mathfrak{M}$ 都定义在 $Z$ 上的概率分布所组成的空间上。固定 $Q \in \mathfrak{M}$，先独立抽取 $\mathcal{P}_1, \dots, \mathcal{P}_K \sim Q$；给定这些环境后，对每个 $e$ 独立抽取 $D_e = (z_{e,1}, \dots, z_{e,n}) \sim \mathcal{P}_e^n$，并令 $S = (D_1, \dots, D_K)$，其中 $K, n \ge 1$。允许假设空间 $\mathcal{H}$ 无限，设 $\ell : \mathcal{H} \times Z \to [0,1]$ 可测，并定义

$$R_{\mathcal{P}}(h) = \mathbb{E}_{z \sim \mathcal{P}} \ell(h, z), \qquad R_Q(h) = \mathbb{E}_{\mathcal{P} \sim Q} R_{\mathcal{P}}(h),$$

$$\widehat{R}_S(h) = \frac{1}{Kn} \sum_{e=1}^{K} \sum_{i=1}^{n} \ell(h, z_{e,i}).$$

可能随机化的算法 $A$ 输出 $\mathcal{H}$ 中的假设。假设对任意仅有一个数据块不同的 $S, S'$ 和任意 $z \in Z$，

$$\left| \mathbb{E}_A \ell(A(S), z) - \mathbb{E}_A \ell(A(S'), z) \right| \le \gamma_K,$$

其中 $\mathbb{E}_A$ 只对算法内部随机性取期望，且

$$\mathbb{E}\left[\widehat{R}_S(A(S)) - \inf_{h\in\mathcal{H}} \widehat{R}_S(h)\right] \le \rho_{K,n},$$

其中 $\gamma_K, \rho_{K,n} \ge 0$，所有显示的随机变量均可测。则

$$\mathbb{E}\left[R_Q(A(S)) - \inf_{h\in\mathcal{H}} R_Q(h)\right] \le \gamma_K + \rho_{K,n}.$$

若对任意 $\varepsilon, \delta \in (0,1)$ 都存在门槛 $k_0, m_0$，使所有允许的 $Q$ 及所有满足 $K \ge k_0$、$Kn \ge m_0$ 的抽样方案都有 $\gamma_K + \rho_{K,n} \le \varepsilon\delta$，则

$$\mathbb{P}\left\{R_Q(A(S)) - \inf_{h\in\mathcal{H}} R_Q(h) \le \varepsilon\right\} \ge 1 - \delta.$$

这是一条同时对 $K$ 与 $Kn$ 量化的条件；只沿某条令 $K, n \to \infty$ 的增长路径收敛并不足够。

**证明** 环境均匀稳定性也控制块损失 $L$ 的变化，因为对块内每个观测的损失变化取平均仍不超过 $\gamma_K$。不同数据块独立同分布，故均匀稳定性定理给出

$$\mathbb{E}[R_Q(A(S)) - \widehat{R}_S(A(S))] \le \gamma_K.$$

对任意固定 $h$，$\mathbb{E}\widehat{R}_S(h) = R_Q(h)$，从而 $\mathbb{E}\inf_h \widehat{R}_S(h) \le \inf_h R_Q(h)$。加入经验优化误差即得期望结论，再对非负的超额期望风险应用 Markov 不等式。 ■

单观测稳定性可通过累加转换为块稳定性：替换 $n$ 项后有 $\gamma_K \le n\beta_{Kn}$。例如 $\beta_{Kn} = O(1/(Kn))$ 仅给出 $\gamma_K = O(1/K)$，域内增样本不会从这个推导中消除有限环境限制。若直接证明块替换的参数期望距离为 $s_{K,n}$，$G$-Lipschitz 损失也给出 $\gamma_K \le G s_{K,n}$。

### 9.3.3 两类保证的比较与适用边界

逐目标保证固定某域，要求共同输出接近该域基准；共享核和覆盖解释源混合风险为何有效，同一成功事件还可加强为同时保证。环境平均则把目标作为 $Q$ 中的随机环境，评价共同假设的平均，允许个别环境较差。平均结论不能自动改成每域保证。

两条路径的样本条件也不同。逐域路线需要源覆盖相应输入与机制，平均路线需要足够独立环境 $K$ 及域内 $n$。$n$ 改善已见环境估计而不能代替独立环境；普通样本替换与环境块替换控制不同扰动，不能仅按名称互换。

复杂度与稳定性分别控制候选估计和算法敏感度，均不单独建立跨域联系。逐域还要共享机制、覆盖和充分表示，平均还要共同环境总体。基准、跨域条件与有限样本控制共同限定适用范围。

## 9.4 本章小结

分布改变后，首要问题是源观测能否确定目标预测。小至两个假设的空间，也可能因缺标签关系或覆盖而不可识别。复杂度和稳定性帮助控制抽样学习，跨域假设则决定源信息是否可以用于目标。

无标签目标样本提供输入分布，分歧与共同错误连接两域风险，共享标签核和覆盖则允许风险重加权。固定相应跨域联系后，可用 VC 维、范数复杂度、稳定性或 PAC–Bayes 计算有限样本代价；重加权路线还须有已知或能在允许族上一致估计的密度比。未控制的正跨域残余仍阻止任意精度结论。

没有目标训练样本时，定义 9.5逐一评价允许目标，可由共享机制与覆盖支持；定义 9.6从共同环境总体抽样，评价新环境平均。不同概率对象要求不同样本量，域内 $n$ 不能普遍代替环境 $K$，稳定性也仍需经验优化。

本部分的 PAC 结论绑定观测、损失、比较空间和允许分布族：存在算法，使每个 $\varepsilon, \delta$ 对应统一有限门槛，在每个允许分布上以至少 $1-\delta$ 概率达到相应风险范围。这没有判断损失是否覆盖实际使用后果、基准是否可接受，也没有自动覆盖族外数据、系统组合和新的部署条件。第 4.5节列出的预训练、持续偏移和有限目标监督问题，都须先固定可见信息、分布变化与比较对象，再作复杂度分析。

**延伸阅读** Ben-David 等的自适应界与不可能性结果分别说明可用条件和缺失信息。对照共同错误、散度与反例，可以检验为何抽样项下降还不等于迁移可学习[8,9]。

Germain 等的 PAC–Bayes 分解适合进一步比较源抽样、预测分歧和共同错误。可逐项判断无标签目标样本能估计哪些量，哪些量必须依赖标签结构[10]。

Maurer、Pontil 与 Romera-Paredes 分析了多任务表示中的环境数量、域内样本与表示复杂度。阅读时保留任务抽样和共享表示条件，尤其区分环境平均结论与任意未来域保证[11]。

[8] S. Ben-David, J. Blitzer, K. Crammer, A. Kulesza, F. Pereira, J. W. Vaughan, *A Theory of Learning from Different Domains* In Machine Learning, 2010, vol. 79, pp. 151–175

[9] S. Ben-David, T. Lu, T. Luu, D. Pál, *Impossibility Theorems for Domain Adaptation* In Proceedings of the Thirteenth International Conference on Artificial Intelligence and Statistics, 2010, pp. 129–136

[10] P. Germain, A. Habrard, F. Laviolette, E. Morvant, *An Improvement to the Domain Adaptation Bound in a PAC-Bayesian Context* In arXiv preprint arXiv:1501.03002, 2015

[11] A. Maurer, M. Pontil, B. Romera-Paredes, *The Benefit of Multitask Representation Learning* In Journal of Machine Learning Research, 2016, vol. 17, no. 81, pp. 1–32

第三部分

# 机器学习可信性

Trustworthiness in Machine Learning

# 阅读指引

同一个在测试中表现良好的模型，用于提醒、可恢复隔离或直接执行不可逆动作，会产生不同后果。实际使用中的人群、环境、权限与攻击条件也可能不同于测试。本部分从这些后果提出可信要求，说明证据能够支持的对象和范围，并为条件失效后的限制使用与补救保留依据。

《可信机器学习基础》先把情境转为可检验要求，再分别检查理论、测试及运行记录，并连接监测、停用和恢复职责。专题章在共同框架内研究不同对象：可靠性检查预测与不确定性，鲁棒性检查变化后的表现，公平性检查机会与负担；目标对齐与行为约束研究行为怎样满足实际要求，可解释性研究理解、质疑与补救的证据，隐私保护研究怎样限制数据使用与发布带来的信息泄露，对抗安全检查主动操纵能否越过保护边界。

这些对象在实际系统中会相遇。拒答可以减少自动处理错误，却也可能增加某组的等待；解释有助审计，也可能暴露敏感信息；工具权限限制可以减少损害，也可能影响任务完成。阅读时可以沿同一使用情境对照各章，分别记录要求、证据及失效条件。一项改进提供的支持只属于对应主张，完整使用判断还需检查其他适用要求是否满足。

第 10 章

# 可信机器学习基础

上一部分已经建立了从样本判断总体风险的条件：固定假设空间、损失、抽样关系和比较基准后，有限样本泛化界给出这种推广的误差与失败概率。这里保证的是既定总体上的统计性质。把学到的模型交给实际系统使用，还需要确定这些性质能支持什么行动。

同一个预测结果可以触发不同处置，处置的后果也可能由不同的人承担。因此，从可学习性进入实际使用时，我们需要明确保证约束的是预测误差、概率覆盖，还是模型与决策流程共同产生的行动损失。质询和复核的渠道、条件改变后的监测责任以及补救措施，也都属于使用判断所需的信息。

我们先看一个邮件分类器。它在测试集上的准确率为 97%，系统据此把可疑邮件放进可恢复文件夹，或者直接删除，这两种用法能否得到同样的支持？隔离误判还有找回的机会，永久删除却可能使收件人错过求职通知或丢失合同附件。模型的误判率即使有有限样本保证，也没有回答应当授予哪一种权限。

**可信机器学习**（trustworthy machine learning）围绕这一使用问题研究：模型和使用过程在什么条件下满足合理要求，哪些证据足以支持这些要求。可信性随任务、受影响者和使用范围而定。例如，概率预测可靠的模型仍可能泄露训练信息；抵御了某类攻击的模型仍可能对少数群体频繁出错。我们需要分别提出并检验这些主张，综合得分不能替代它们。

本部分着重讨论技术可信性，即模型、数据、算法和技术系统的证据能够支持哪些主张。这些证据可以供组织审批、法律合规和公共治理复核。部署权限、责任归属和风险接受则还要由有权主体结合领域规则，以及受影响者提出的影响证据、质询与补救需求来决定；单凭技术测试通过，无法完成这些判断。本部分的范围因而只是人工智能治理所需材料的一部分。

要回答邮件分类器可以承担多大决策范围，我们将先把使用情境转成明确要求，再判断证据支持的强度，最后说明结论何时失效、谁采取限制措施、如何恢复。系统属性用于选定可靠性、隐私等考察维度，规范要求

把维度落到具体条件；证据与生命周期安排则使这些要求可以被论证、复核和持续使用。章末回顾相关研究的汇合，并借研究地图指出仍缺证据的问题。这套分析也将贯穿可靠性、鲁棒性、公平性、行为约束、可解释性、隐私和安全各章。

图 10.1把上述技术证据放在同一使用情境中考察。交叉区域表示各方会讨论共同议题，不能据此推断一种判断包含另一种判断：技术检验通过，仍不足以推出部署合法、已经获准或得到公众认可。

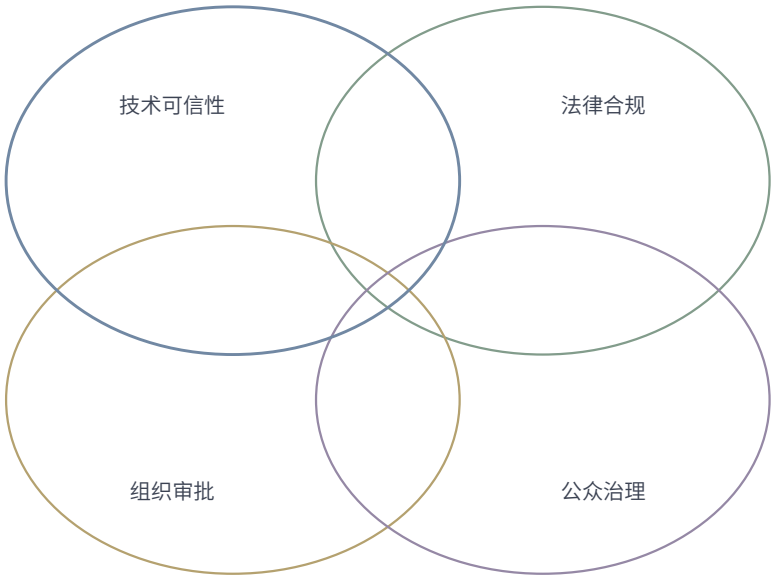


图 10.1　蓝色轮廓标出本书讨论的技术证据，其他区域表示法律合规、组织审批与公共治理。交叉处只示意共享议题；边界及面积不表示集合度量、逻辑包含或责任继承，各主体仍依自身要求判断。

## 10.1　技术可信性的范围与三个层次

邮件误拦的风险要沿着“预测—处置—后果”计算。确定后果后，我们还需要指出谁承受损失，以及哪些人和环境属于评价范围。前一项决定损失怎样计量，后一项限定这个损失结论能用于哪里；一个脱离这些信息的性能数值无法决定使用权限。

“可靠性”或“隐私”只是系统属性的名称，告诉我们要考察哪种性质。把属性写成规范要求时，还要给出受影响对象、评价单位、适用范围，以及允许的事件、阈值或程序条件。例如，邮件隔离要求可以约束误拦比例，而数据访问要求可以约束授权流程。这是分析的第一层。

第二层检查已有证据是否足以支持要求。理论结论要保留显式假设和量词，抽样检验要交代数据取得方式；压力测试、机制分析与人因评价则

补充各自能够观察的失效。反证和剩余不确定性需要与有利结果一同记录，才能看清结论的强度。

第三层把结论带回运行过程：哪些条件改变会使主张失效，谁负责监测，触发后怎样限制使用、回退和恢复。技术材料提供这些判断所需的依据，有权主体再据此决定是否接受剩余风险和批准部署。

三层各有不能省略的职责。要求确定测试要支持什么行动，证据说明要求是否得到支持，生命周期条件限定证据何时继续有效。如果数据、模型、权限或用法已经改变，却仍沿用一次测试的结论，三层之间的联系就被切断。下面从邮件处置的后果建立第一项联系。

图 10.2同时标出提出要求、准备和复核证据、执行处置的角色。这些职责需要落实到实际授权记录；算法能够提供计算结果，却无法自行承担上述分工。

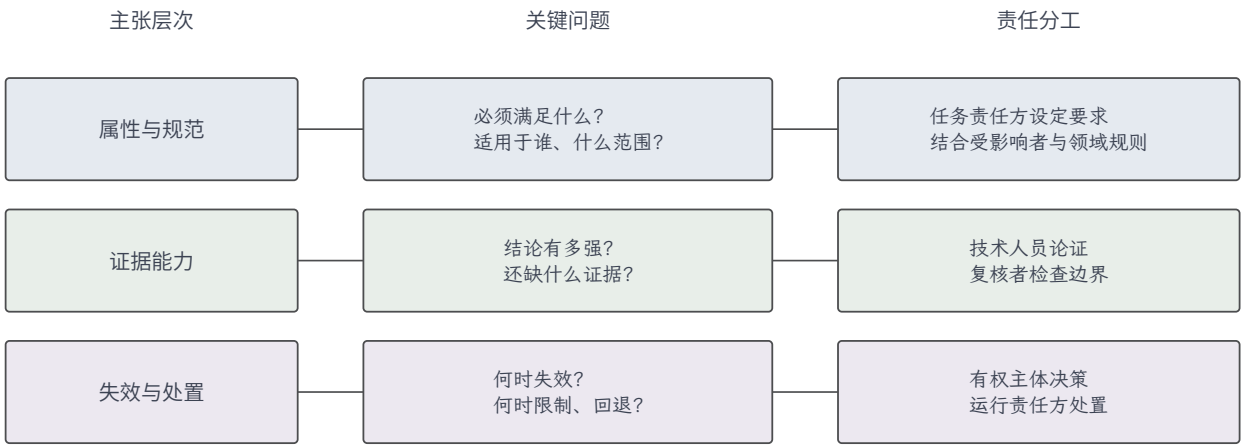


图 10.2　要求、证据及失效处置构成可信主张的三个层次。系统属性选择考察维度，规范要求确定条件；证据限定结论强度；生命周期条件确定暂停沿用和响应。三行分别连接任务方的要求、技术论证与独立复核、有权主体的风险决定和运行方处置。横线只表示同层对应，教学分工仍需由真实授权与审批落实。

### 10.1.1 从预测结果到实际后果

设一封邮件的输入为 $\boldsymbol{x}$，模型输出为 $f(\boldsymbol{x})$。系统还需通过决策规则 $d$ 把输出变成行动 $a = d(f(\boldsymbol{x}), \boldsymbol{x})$：例如根据垃圾邮件概率放行、隔离或转人工。我们可以保持 $f$ 不变，只改变 $d$，观察行动后果怎样改变。

为了给不同处置使用同一比较口径，记真实状态为 $y$，采取行动 $a$ 后的损失为 $L(a, y)$。部署分布 $\mathcal{P}$ 规定哪些邮件及状态进入评价，我们对这一分布取平均，得到系统的期望损失

$$R_{\mathrm{sys}}(f, d) = \mathbb{E}_{(\boldsymbol{x}, y)\sim\mathcal{P}} L\big(d(f(\boldsymbol{x}), \boldsymbol{x}), y\big). \tag{10.1}$$

式中保留了模型、决策规则与数据分布三者。分类器的零一损失只区分预测是否错误，行动损失还区分误拦和漏放的后果。两种损失分别回答预测质量与使用代价问题，不能相互替换。

图 10.3保持预测不变，分别画出隔离和永久删除的行动链。我们要比较的是链条末端的后果，而不只是链条开始处的分类结果。

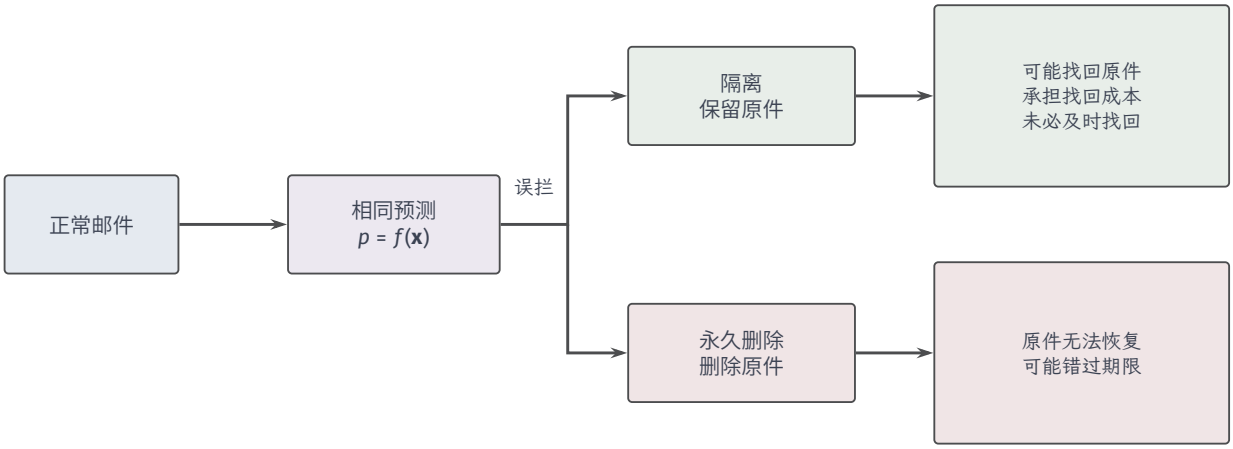


图 10.3　保持 $p = f(\boldsymbol{x})$ 不变，比较同一正常邮件误拦后的隔离与永久删除。左侧保留原件可供找回，右侧删除原件；末端收件人可能承担找回成本或错过期限。$L(a, y)$ 还需计入真实状态 $y$、发现延误和恢复成本。情景为构造，保留原件并不保证及时找回。

**示例 10.1　准确率与行动损失**　在一个构造的 1000 封邮件测试集中，模型甲误拦 10 封正常邮件、漏放 20 封垃圾邮件，模型乙误拦 2 封正常邮件、漏放 40 封垃圾邮件。按正确封数计算，甲的准确率为 97%，乙为 95.8%。现在把每次误拦损失设为 10、每次漏放损失设为 1：甲产生的总损失为 $10 \times 10 + 20 = 120$，乙为 $2 \times 10 + 40 = 60$。同一测试集上，乙虽然正确率较低，却减少了在此损失设定下更昂贵的错误，因此总行动损失较低。比较结论仍限于这批样本和成本设定，不能单独决定使用权限。

这个例子借人为指定的代价说明，正确率的排序与行动损失的排序可以不同。真实邮件流程还要计入延误、申诉和恢复成本。隔离若能及时找回，可能比永久删除损失小；用户若一直没有发现误拦，保留原件也未必实现补救。评价因此要追踪完整流程。

知道不同错误的成本后，我们可以从损失推导处置阈值。这里比较邮件隔离和放行，按各行动在当前输入下的期望损失选择。设 $p$ 为给定输入下邮件属于垃圾邮件的真实概率，误拦成本为 $c_{\mathrm{fp}} > 0$，漏放成本为 $c_{\mathrm{fn}} > 0$，

正确处理暂不计成本。隔离只有遇到正常邮件才产生损失，其条件期望为 $(1-p)c_{\mathrm{fp}}$；放行的条件期望为 $pc_{\mathrm{fn}}$。选择损失较小的行动，隔离条件便是

$$p > \frac{c_{\mathrm{fp}}}{c_{\mathrm{fp}} + c_{\mathrm{fn}}}. \tag{10.2}$$

两项损失相等时，当前模型下的行动等价。误拦成本越高，隔离所需的概率越高，阈值因此不必是 0.5（可参考第一卷“策略的价值与优化”章的“条件风险与 Bayes 决策”定义）。实践中代入的是估计概率，决策质量便依赖估计质量。若干概率区间的平均预测与事件频率吻合，只给出分组证据，不能证明每个输入上的概率准确；第 11章将展开这些区别和检验。

**示例 10.2　增加复核选项后的决策**　沿用教学成本 $c_{\mathrm{fp}} = 10$、$c_{\mathrm{fn}} = 1$，再加入一个固定成本为 0.2 且能够无误确认标签的人工复核选项。隔离、放行和复核的候选损失分别为 $10(1-p)$、$p$ 和 0.2。比较三者，$p < 0.2$ 时放行损失最小，$p > 0.98$ 时隔离损失最小，中间的 $0.2 < p < 0.98$ 则由复核占优；两个端点各有两种行动成本相等。复核区域来自成本比较，不需要模型额外预测一个“犹豫”类别。

无误复核使这项计算可以只用固定成本 0.2。若人工也会出错，或者队列变长使等待成本增加，就要把相应后果计入第三项。进一步判断模型是否值得使用，还需在相同条件下比较完全人工处理、简单规则或较低权限的自动化；两个模型的准确率比较没有覆盖这些替代流程。

成本难以精确给定时，我们可以改变成本比，重复比较同一组可行方案的期望行动损失。由领域约束和有权主体预先声明的成本比区间限定分析范围：方案若只在窄区间占优，结论依赖较精确的成本判断；若在整个区间均比各替代方案损失低，结论对该项不确定性较不敏感。这里改变的是使用假设，区别于第 12章的输入和环境变化。

式 (10.1)还把真实状态 $y$ 当成不随当前行动变化的对象，邮件类别通常可以采用这一建模。资源分配却可能不同：用分数决定谁参加培训后，培训本身会影响后续成绩。过去参加培训者中的预测准确率，无法直接说明把名额给其他人会带来什么收益。要比较这些行动，我们需要描述各候选行动下的可能结果，并取得额外观测或提出因果假设；历史行动下的成绩不能直接充当所有行动共用的 $y$。这一区分将在第 13章的长期干预分析中再次使用。

### 10.1.2 风险的承担者与使用范围

损失确定后，还要说明损失落在谁身上。购买、操作系统的人与受影响者可能不同：招聘筛选为用人方节省工作，却可能让求职者承担误拒。评价

需要同时记录收益、错误负担以及发现和纠错的机会；开发者容易测量的指标未必覆盖这些影响。

同一种损失也会随语言、设备、时间、输入质量和用户群体而改变。部署范围中的“适用于某类输入”应当对应可检查条件，范围外输入则需要识别、限制使用或转交安排。环境变化怎样破坏原有规律，留待第 12章分析。

把失效列入具体使用情境，还会发现预测以外的危害：答案正确却泄露隐私，完成指令却越过授权，或受外部内容诱导偏离任务。明确这些路径，才能选择相应保护。NIST 人工智能风险管理框架也从使用情境识别、测量和管理风险；应用其原则时，仍须把要求落实到当前系统[1]。

[1] National Institute of Standards and Technology, *Artificial Intelligence Risk Management Framework (AI RMF 1.0)*, tech. rep. NIST AI 100-1, National Institute of Standards and Technology, 2023

## 10.2 系统属性与规范要求

使用情境已经给出危害及承担者，接下来要把危害转成可判定要求。要求设定包括三个相连的工作：写清可观察的主张，检查遗漏的情境，再处理各项要求之间的支持或冲突。可观察事件把后果与行动规则连起来；只描述后果，无法测量改进，只优化一个没有行动含义的数值，也可能偏离使用目的。

### 10.2.1 可信性要求的具体表达

在邮件任务中，“可靠”可以具体约束自动隔离邮件中的正常邮件比例，也可以约束某一人群的预测区间覆盖率。两条要求的承载对象不同，需要分别声明评价单位、总体范围、错误事件和容许水平。这样才能判断一个测试究竟支持了哪条主张。

评价单位还决定风险怎样累积。以一次调用计量的失败率，不能直接作为用户一周全部调用的失败率；连续调用可以把很小的单次概率累积成较大的至少一次失败概率。多步任务因此要同时评价单步性质和最终结果。

有了评价单位，我们仍需选择要求的表达方式。平均行动损失适合比较可补偿的代价，发生概率、分组要求和授权访问等过程条件则可能要单独约束。设任务、模型供给、允许行动及权限边界确定了候选模型族 $\mathcal{F}$ 与决策规则集合 $\mathcal{D}$。在可量化要求下，可以选择满足约束且平均损失最小的一对模型与规则：

$$\begin{aligned} \min_{\substack{f\in\mathcal{F}\\ d\in\mathcal{D}}} \quad & R_{\mathrm{sys}}(f,d) \\ \text{s.t.} \quad & G_j(f,d)\le b_j, \quad j=1,\dots,m. \end{aligned} \tag{10.3}$$

$G_j$ 表示第 $j$ 项要求的测量量，$b_j$ 给出其容许上限，$m$ 为要求数。先用约束排除不允许的方案，再按 $R_{\mathrm{sys}}$ 比较剩余方案，这说明了最小化的用途。最小值写法要求可行集非空且最优解能够取得；否则应报告不可行或使用

下确界。无法合理量化的程序条件仍需保留在公式之外，不能制造分数来代替它。

### 10.2.2 可信性要求的完整性

满足现有风险要求的模型可能不止一个，而且这些模型在部署关切上仍有差异。**欠规定性**（underspecification）描述的正是这种信息缺口：任务与评价条件足以让多个模型通过，却不足以区分其重要行为。判断时须预先指定训练域留出数据、指标和容差；候选模型可能同时达标，或指标差异落在容差内，却在新环境、子群体或压力情境中给出不同结果。D'Amour 等在多种流程中展示了这一现象，提醒我们除检查单个模型是否过拟合，还要检查训练和评价条件能否筛选出所需模型[2]。

我们用一个构造邮件问题区分这两种缺口。若训练来源中内容特征 $x_1$ 与页脚特征 $x_2$ 始终相同，标签也等于两者，则只使用其中任一特征的分类器在同分布测试中都完全正确。增加同来源的测试邮件只能更准确地确认这种等价，无法决定部署时哪条规律会保持。若部署仅保留内容与标签的关系，两个候选的行为就分开了；此时所缺的是区分规律的新情境。

补充信息可以改变训练，也可以改变评价。训练端加入环境、结构约束或领域知识，评价端构造能够区分候选规律的测试；采用哪一种取决于部署中可获得什么信息。压力测试只验证了某个随机种子产生的模型时，结论也只属于该模型，不能转给其他种子重训的结果。

要求还可能漏掉同一标签内部的差异。**隐藏分层**（hidden stratification）指标签和评价分组未表示某些子类型，而它们的错误概率、损失、补救机会或行动规则不同；聚合后便看不见重要失败。Oakden-Rayner 等的医学影像研究讨论了低频子类型、标注质量和伪相关引起的问题。由此需要检查标签是否充分描述任务差异，而不能把自动聚类形成的每个组都认定为有实际意义[3]。

"正常邮件"中的普通通知与有截止日期的合同便可能承担不同的误拦代价。我们可以根据后果提出候选切片，再核验样本质量和估计不确定性。错误分析发现的新切片用于诊断，独立确认才用于支持结论；反复搜索后找到的最差切片也可能只是抽样波动。环境切片和群体切片分别由鲁棒性与公平性两章展开，此处得到的共同结论是：没有被评价分组表示的要求，不能由总体指标代为满足。

### 10.2.3 不同性质之间的联系与取舍

要求完整性要覆盖几种不同对象。可靠性评价预测及不确定性是否有依据，鲁棒性评价输入和环境改变后的有效性，公平性评价机会、错误和负担的分配，目标对齐与行为约束评价学到的行为。可解释性提供理解和质

[2] A. D'Amour, K. Heller, D. Moldovan, B. Adlam, B. Alipanahi, A. Beutel, C. Chen, J. Deaton, J. Eisenstein, M. D. Hoffman, F. Hormozdiari, N. Houlsby, S. Hou, G. Jerfel, A. Karthikesalingam, M. Lucic, Y. Ma, C. McLean, D. Mincu, A. Mitani, A. Montanari, Z. Nado, V. Natarajan, C. Nielson, T. F. Osborne, R. Raman, K. Ramasamy, R. Sayres, J. Schrouff, M. Seneviratne, S. Sequeira, H. Suresh, V. Veitch, M. Vladymyrov, X. Wang, K. Webster, S. Yadlowsky, T. Yun, X. Zhai, D. Sculley, *Underspecification Presents Challenges for Credibility in Modern Machine Learning* In arXiv preprint arXiv:2011.03395, 2020

[3] L. Oakden-Rayner, J. Dunnmon, G. Carneiro, C. Ré, *Hidden Stratification Causes Clinically Meaningful Failures in Machine Learning for Medical Imaging* In arXiv preprint arXiv:1909.12475, 2019

疑行为的证据，隐私限制数据使用中的泄露，对抗安全则要求在主动操纵下保持相应边界。

同一处置会同时改变这些对象。例如，转人工可能降低自动处理部分的错误率，却减少自动处理量；隐私保护可能增加估计噪声；缩小工具权限可能减少损害，也可能阻碍完成任务。比较时需要沿用同一使用目标，报告收益及代价落在哪些指标和人群上。

加权综合分数还允许指标相互补偿，但某些要求并不允许这种交换。未经授权披露数据若被声明为不可接受，提高准确率不能抵消披露。式 (10.3)据此把约束与优化目标分开。受影响者提供后果和补救需求，领域与法律规则给出外部边界，经授权责任主体在自己的权限内设定阈值、记录取舍并作有期限的风险接受。算法在给定要求下求解，风险接受也不能越过不可补偿约束。

## 10.3 证据能支持什么结论

明确要求之后，我们要判断证据能支持的强度，并检查证据怎样产生、如何保存以供复核。结论含义、检验设计与记录条件各自影响证据有效性；至于系统变化后能否继续沿用结论，下一节再讨论。

我们可以用一份**可信保证**（trustworthiness assurance）记录连接要求和证据。这里的保证是一项可逐条核对的论证，包含十项内容，并非无条件承诺。前两项先记录情境与危害，包括任务、受影响者、评价单位和行动链，再写要求，包括指标或程序约束的分母、阈值与适用范围。

接着的四项说明证据为何支持要求。显式假设列出抽样、标签、权限、资源和替代方案等条件；论证保留量词和比较基准，解释条件怎样推出主张；多源证据汇集理论、随机抽样、压力测试、机制分析、人因评价和监测；反证与剩余不确定性则保存失败案例、未覆盖情境、估计误差和替代解释。

余下四项确定结论怎样进入决策和运行。责任主体记录证据准备、独立复核、监测、处置及外部决定的授权；风险接受记录有权主体如何结合危害、补救需求、领域与法律约束，在一定范围和期限内接受剩余风险。这一决定不由技术证明推出，主要由他人承担的损失也不能被默认为获准。失效触发列出暂停旧结论的数据、模型、权限、流程变化或监测结果，处置列出降级、停用、回退、通知、补救、复验和重新开放。失效来源进入情境、假设和触发项；主动攻击者存在时，还需记录其知识、权限、资源、目标及损害路径。

### 10.3.1 理论保证与经验检验

某个覆盖定理可能约束校准数据与未来样本的联合抽样，却没有约束每个固定输入的覆盖率。理论保证必须连同量词和假设一起使用，才知道它回答了哪一项要求。复核时因而要把数据生成、算法实现和评价对象逐项对照定理。

经验检验则在具体样本或攻击条件中观察系统行为。它可以发现现实与理论假设的偏差，也可比较尚无完整理论的方法。观察不到失败仍只是一项样本结果；我们先通过零次失败的计算看清它能支持多强的判断。

**示例 10.3　零次失败的含义**　固定系统在 $n$ 次独立同分布试验中的单次失败概率为 $p$，整批零次失败的概率为 $(1-p)^n$。把这个概率置为 $\delta$ 并求解，可以得到零失败观测所对应的单侧置信上限

$$p_{\mathrm{up}} = 1 - \delta^{1/n}.$$

取 95% 置信水平，100 次零失败的上限约 2.95%，1000 次零失败约 0.30%。95% 属于构造上限的程序在重复抽样中的覆盖性质，不能解释成固定未知 $p$ 有 95% 后验概率低于上限。上述计算还依赖试验单位和抽样条件；若不断尝试，直到某批恰好零失败才报告，原来的置信解释不再成立。

### 10.3.2 检验设计与证据有效性

除了随机抽样，我们还可以按已声明的行为要求主动设计用例。**行为测试**（behavioral testing）把某种输入或变化应触发什么响应写成可执行检查。Ribeiro 等的 CheckList 将语言能力与最小功能、保持不变、定向变化等测试结合，帮助把行为预期落实为用例，补充总准确率未直接检查的部分[4]。

对邮件系统，最小功能用例可以是一封简短且含义明确的会议通知；保持不变用例只改大小写或无关排版，仍要求放行；定向变化用例则在任务已把某类未经请求的推销认定为垃圾邮件后，逐步加入明确推销内容，观察分数方向。这些预期都要受任务语义约束。例如，诈骗警示引用了诈骗原文，并不等于在实施诈骗；一律拦截引用会暴露模型对意图的遗漏。

行为用例用于寻找规定机制中的缺陷，随机抽样则在抽样条件下估计总体风险。困难样本被有意大量纳入压力测试，其失败率不能直接充当部署失败率；普通随机样本中没有遇到低频缺陷，也不能代替针对性检查。样本的取得方式决定了结果的解释范围。

[4] M. T. Ribeiro, T. Wu, C. Guestrin, S. Singh, *Beyond Accuracy: Behavioral Testing of NLP Models with CheckList* In Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics, 2020, pp. 4902–4912

数据的用途同样会改变证据。模型选择和阈值调整若反复读取测试结果，测试集便参与了开发。最终评价需要另留未参与选择的数据，或采用处理重复选择的统计方法；第 11.3节会给出有限候选程序的例子。

比较系统时，还需固定任务、样本、资源预算和评价口径。随机生成过程要记录生成次数、解码设置与选择规则；用一个系统多次生成后最好的结果对比另一个系统的首次结果，改变的不只是模型，也包括计算和选择机会。

人或模型给出的分数也是测量过程的一部分。我们需要核查判据、重复一致性及其与实际后果的关系：偏爱长答案的评判者可能提高冗长答案得分，而事实正确率没有增加。保存模型版本、数据来源、评价规则和运行条件，才能复核分数究竟表示什么。

### 10.3.3 证据的记录与复核

测试数值的适用条件往往藏在数据取得过程中。重复记录、标签来源、排除标准及预训练语料重合，都可能影响结果。Gebru 等提出 Datasheets for Datasets，随数据记录动机、组成、收集过程和推荐用途，以便使用者判断数据是否适合当前任务。这些说明限定数据条件，却不证明数据没有偏差[5]。

模型层面也需要保存对应条件。Mitchell 等的 Model Cards 记录预期用途、评价过程和相关群体或情境下的结果，使模型名称对应到具体版本、范围与证据。模型卡可以承载可信主张；卡片填写齐全而评价缺失时，主张仍缺证据[6]。

例如，模型卡报告较低的正常邮件误拦率，数据说明却显示样本只来自一种语言和一组用户。把两份记录对照，复核者便能识别另一种语言尚未获得支持。补做测试后，应更新该语言的覆盖范围和证据，单独改变模型版本号无法补上这个缺口。

复现也有不同范围。重跑同一程序核查计算和随机性；新增独立样本核查结论在重新抽样后的重复性；换环境核查外部适用性。三项依次改变的对象不同，结论不能互相推出。公开代码主要帮助重跑程序，后两项仍需合适数据和环境联系。

生成系统还要保存决定输出分布的过程：模型版本、系统提示、检索内容、工具权限、温度、重试次数和答案选择方式。若更新模型的同时增加重试，收益属于这套完整过程，不能全部归于模型能力。记录这些条件也为下一次重新验证确定了比较对象。

[5] T. Gebru, J. Morgenstern, B. Vecchione, J. W. Vaughan, H. Wallach, H. Daumé III, K. Crawford, *Datasheets for Datasets* In arXiv preprint arXiv:1803.09010, 2021

[6] M. Mitchell, S. Wu, A. Zaldivar, P. Barnes, L. Vasserman, B. Hutchinson, E. Spitzer, I. D. Raji, T. Gebru, *Model Cards for Model Reporting* In Proceedings of the Conference on Fairness, Accountability, and Transparency, 2019

## 10.4 失效、处置与生命周期条件

证据已经说明要求得到何种支持，运行中仍要判断这些条件何时改变。生命周期安排记录参与者、环境或组件怎样使主张失效，谁在何种范围接受剩余风险，哪些观测触发限制使用，以及怎样恢复到可评价状态。受影响者的质询和补救需求是决策输入，不能转成由其独自审批；有权主体作决定，也仍要考虑这些输入与外部约束。这里提供审批、监测和复查所需的技术材料，不替组织设定法定职责。

### 10.4.1 失效来源、责任主体与风险接受

保证依赖的数据、标注、供应商、权限、人员负荷或组件状态，都可能发生变化。我们将这些破坏保证条件的因素称为失效来源，并沿“作用对象—影响路径—能否监测”记录它们。若有人主动选择变化以造成损害，还要进一步设定威胁模型，说明攻击者的知识、权限、资源和目标。

条件改变时，必须有人能够执行处置。**责任主体**（accountable role）指对某项保证决定或行动承担明确职责的角色；评价准备、独立复核、使用审批、运行监测和事故处置可以分开授权。笼统地写“项目组负责”，无法确定谁在触发后有权停用系统。**风险接受**（risk acceptance）则由有权主体在证据边界和剩余不确定性已知时，决定残余风险能否在特定范围与期限内承担。接受不等于风险消失，也不允许用收益抵消不可接受的约束违反。

### 10.4.2 变更触发与组合后的重新验证

把通过测试的组件接在一起，会出现单独测试没有评价的新关系。检索结果可能改变生成器的输入分布，重试可能增加泄露机会，告警过多可能使人工审核失效。组合后的验证因此要检查这些接口和依赖，不能只重跑原组件测试。

要避免条件改变后误用旧证据，主张应当带有**失效触发**（invalidation trigger），明确哪些数据变化、权限扩张、模型更新或监测结果使其暂停适用。触发项给出可依赖结论的期限和边界。组织的审批、发布与追责还属于治理流程，技术记录则至少要提供决策点、所需证据和触发条件。

组件错误的关系也会随组合进入评价。若同一垃圾邮件总体中两个检测器各漏检 10%，任一报警便拦截，则只有两个漏检事件独立时，共同漏检率才是 1%。如果两者采用相同表征并遗漏相同邮件，共同漏检可能仍为 10%。第二个检测器能否减少风险，取决于它增加了什么信息，结构上多设一层并不足以证明收益。

人工复核同样不能只按组件数量计算收益。复核者看到原件和只看到模型摘要，能获得的信息不同；摘要若已漏掉关键证据，确认步骤未必修

正判断。人机协作的风险主张需要评价复核者所见信息、告警数量与行动时间等真实条件，第 14.2节将进一步讨论这些监督要求。

### 10.4.3 失效处置与恢复

失效触发之后，先限制损害，再保存定位证据，随后恢复到可重新评价的状态。暂停自动动作、降低权限、转人工、回退模型或隔离数据，应根据危害选择。已删除内容、已泄露信息与可撤销状态的恢复边界不同，不能统称为“回滚即可”。通知受影响者、纠正已有结果及保留日志的安排，也需服从隐私和访问约束。

重新开放需要针对触发原因与修复范围建立新证据。复验既检查已知失败是否重现，也检查修复是否影响正常任务、其他群体和相邻性质。责任主体据此重估剩余风险；证据不足时，继续限制使用或选用危害更小的流程。监测、处置和恢复由此进入保证的成立条件，而不只是部署后的附加措施。

## 10.5 例子：邮件隔离的完整保证记录

我们把前面建立的要求、证据和生命周期条件合在一次邮件隔离验收中。以下模型、数据、阈值和结果均为构造值，用于说明怎样形成可判定的保证记录，不代表真实服务经验。验收固定模型 $\upsilon_1$ 与概率修正程序 $c_1$，范围为公司自有网关在批准后 30 日内接收的中英文文本邮件；加密正文、纯图像邮件和网关外导入邮件均转出自动处理范围。

误拦可能延误合同和求职通知，漏放可能暴露诈骗内容。记录据此排除永久删除权限，并将用户代表的延误及恢复需求、运行方的人工处理能力和适用规则交由经授权产品责任人审定。在授权范围内，责任人采用 $c_{\mathrm{fp}} = 10$、$c_{\mathrm{fn}} = 1$、复核成本 0.2 这组教学值，再预先声明验收条件。隔离比例至少 30%，表示自动化应分担足够处理量；误隔离与漏放上界分别限制延误和诈骗危害；恢复时延的经验 95% 分位数不超过 5 分钟，最大值不超过 10 分钟。这些阈值来自规范设定，不能看完结果再反推。

$c_1$ 使用与验收集独立、来自同一声明总体的校准资料冻结。校准记录按预设概率区间保存样本量、平均预测与事件频率，偏差超出预设容差便触发失效。这支持分组概率语义，尚未证明每封邮件的 $p = c_1(f(\boldsymbol{x}))$ 都是真实条件概率。用 $10(1-p)$、$p$ 和 0.2 比较处置因而是一项建模近似，还要独立验收冻结后的规则。规则规定：$p < 0.2$ 时放行，$0.2 \le p \le 0.98$ 时复核，$p > 0.98$ 时可恢复隔离。

独立验收以单封邮件为抽样单位，从声明总体独立同分布抽取 1000 封邮件，其中正常 600 封、垃圾 400 封。两名评价人员按照预先冻结的标签规则独立标注，第三人裁决分歧。冻结的处置规则隔离 362 封，其中正常

邮件 2 封；复核 100 封，其中正常 70 封；放行 538 封，其中垃圾邮件 10 封。

我们分别检查四项预设要求。自动隔离比例应至少 30%；在隔离邮件中，正常邮件比例的单侧 95% 二项 Clopper–Pearson 置信上界不超过 2%；在全部正常邮件中，误隔离比例的同类上界不超过 1.5%；在全部垃圾邮件中，漏放比例的同类上界不超过 5%。分母依次是全部邮件、隔离邮件、正常邮件和垃圾邮件，因此四个点估计分别为 36.2%、$2/362 \approx 0.55\%$、$2/600 \approx 0.33\%$、$10/400 = 2.5\%$。后三项置信上界约 1.73%、1.05% 和 4.20%，均达到各自阈值。这里的 95% 分别属于每项上界程序，不是三项同时满足的 95% 置信保证；需要同时保证时，须事先分配总体失败概率并重新计算各项上界。隔离比例的 36.2% 在本例中是验收样本的处理量证据，未建立部署总体隔离比例的置信下界。

补救还需独立演练。50 次演练从点击“恢复”起计时，到邮件同时回到收件箱和搜索索引为止。按最近秩规则，第 $\lceil 0.95 \times 50 \rceil = 48$ 个次序统计量给出经验 95% 分位数 3 分钟，最大值 7 分钟，分别低于 5 分钟和 10 分钟。它们描述这 50 次演练，尚未构成未来时延总体分位数的置信保证。

上述论证依赖几项条件：验收邮件与随后 30 日邮件满足声明的抽样关系，标签可信；$\upsilon_1$、$c_1$、成本和阈值在验收前固定；人工队列可用，隔离区与搜索索引支持恢复。行动损失用于构造三段处置，范围检查限定自动处理对象，误拦与漏放比例的单侧置信上界处理抽样不确定性，恢复演练检查补救路径。每项证据都有相应的职责。

为了补充总体计数，记录还按语言检查：中英文各 500 封，每组隔离 181 封并误拦 1 封。40 项预先声明的压力测试分别检查合同与求职邮件、诈骗原文引用、无关排版变化和范围边界，每类 10 项，每项事先确定预期动作，本次均未失败。定向用例只覆盖已列情境，不能据此估计部署失败率或保证其他情境安全。

验收通过仍保留失效可能。漏放上界虽达到教学阈值，新模板、隐藏子类型、共同训练盲点和人工错误仍未被排除；低频重要邮件的区间可能较宽，也尚无上线监测结果。评价人员冻结数据、复核标签并计算上界，用户代表提供后果与补救需求，产品责任人按授权批准期限，运行人员监测、停用与回退，用户能够查看隔离并申请恢复。

在这些条件下，教学实例的产品责任人接受 $\upsilon_1$ 在声明范围运行 30 日，权限仅限可恢复隔离。主动攻击和隐私并未获得这项验收的正面保证；外部安全或隐私检查若发现违反约束，准确率收益不能抵消违反，永久删除也仍不获接受。

触发项需要按影响范围执行。某封邮件超出输入范围，只把该请求转人工；模型、修正程序、阈值、标签规则或工具权限改变，则暂停整项保证。

运行人员每 7 日从该审计周期内满足输入范围的全部邮件独立抽取样本，再按冻结规则取得可靠标签，重算三项错误比例的单侧 95% 上界。标签尚未齐全时保留待审样本，不只保留易获标签或已成功处理的邮件；若无法为随机样本补齐可信标签，相关总体风险结论暂停沿用。这些逐期上界用于预设运行告警，单次 95% 不能解释为所有时点与指标同时有效的 95% 保证；需要这种保证时，应预先控制重复检验的总体错误概率或使用适用的序贯方法。任一上界超限、隔离比例低于 30%、人工队列不可用，或恢复时延的经验 95% 分位数超过 5 分钟、最大值超过 10 分钟，均暂停自动隔离。

已经确认的外部安全或隐私告警也触发暂停，但这些告警不表示本项验收已经证明安全或隐私。暂停后，运行人员转人工、回退已验证版本、恢复误拦邮件并保留事件记录；评价人员补齐证据，有权责任主体重新接受后，系统再分阶段开放。

## 10.6 研究内容

### 10.6.1 发展历史

本章的问题来自几条研究路线的汇合：统计预测与决策理论研究误差和行动，模式识别研究复杂输入中的有效性，信息安全限制信息与权限，人机交互和软件保障检查理解与运行过程。下面按使用链回顾这些联系，作为概念路线而非唯一编年史，教学上的衔接也不代表历史因果。各路线分别回答局部问题，把模型接入筛查、推荐、医疗和资源分配之后，还需共同说明输出怎样触发行动、后果影响谁、系统变化后证据是否继续有效。

概率预报提供了较早的一种评价对象。Brier 分数比较报告概率与实际结果，作为损失时构成**适当评分规则**（proper scoring rule）：如实报告真实概率的期望分数不会高于其他报告[7]。这使评价从类别是否命中扩展到概率的质量。分类准确率相同，概率质量仍可不同；概率质量相同，成本和权限不同又会产生不同处置。本章据此将概率输出的含义与行动条件分开考察。

[7] G. W. Brier, *Verification of Forecasts Expressed in Terms of Probability* In Monthly Weather Review, 1950, vol. 78, no. 1, pp. 1–3

概率被用于筛查、排序和分配后，平均预测误差之外还出现了新的要求：报告概率与事件频率是否吻合，不确定性能否指出困难输入，区间或集合是否覆盖目标。神经网络校准研究显示，分类改进不会自动使概率可靠；共形预测利用可交换样本的排序关系建立有限样本覆盖[8,9]。可交换表示样本次序重排不改变联合分布，独立同分布是更强的常见充分条件。研究的问题由答对多少，延伸到如何表达尚不能确定的答案。

这一延伸仍要区分评价对象。二元事件校准比较报告同一概率的样本中事件的长期频率；多类别向量、类别条件和群体校准各需声明事件及条件。共形预测约束预测集合的覆盖事件，两者都不保证单个答案正确。集合始终很宽或系统频繁转人工也可能满足覆盖，因而还需同时报告集合大小、拒答比例和错误代价，评价它为决策提供了多少有用信息。

不确定性表达进一步进入处置：集合、区间或拒答信号可以触发补充信息、其他工具或人工接管。增加处置选项便改变了分母，自动处理部分错误率、全部请求覆盖率和转交成本要一同报告。选择性预测、序贯决策和人机协作将研究对象推进到带备选流程的完整决策程序。

由分组频率或联合抽样得到的结论，仍不能直接用于判定固定输入正确。高代价决策需要把总体、分母和随机来源写在保证中，并区分零失败观测、平均校准与每次决定的依据。风险控制、拒答和变化环境覆盖，分别继续处理这些保证未覆盖的条件。

部署可能改变训练时的输入条件。常见损坏基准以噪声、模糊和天气等构造可重复压力，跨来源数据则按医院、时间、地理或设备划分环境[10,11]。随机平滑等方法另为局部扰动提供认证[12]。描述变化时，我们需要分别写来源和意图、训练与部署的统计关系、任务语义。自然与对抗变化都可能偏移分布，对手也可能保持或改变答案，不能把这些维度归成互斥类别。

固定损坏类型和强度，可以比较模型在同一压力下的退化；真实跨来源数据同时改变采集中的多个因素，更接近部署，却更难定位原因；局部认证则约束输入邻域中输出是否变化，尚未检验医院、时间或人群差异。基准、跨来源评价和认证因此提供不同的互补证据，分别支持重复比较、来源差异诊断和规定集合内反例的排除。

这些证据都要先确定任务要求如何随变化调整。设备、人口、规则或输入质量改变时，模型权重虽固定，风险却可能变化；某些输入变化应保持答案，某些新信息应改变答案，还有些已离开任务范围。鲁棒性若只要求稳定，就可能连有意义的信息也消除，因而必须先声明变化范围、幅度、对手与语义。

随机留出用于估计约定总体的平均风险，压力样本用于寻找困难情境，认证用于排除集合内的特定反例。它们的数值不可互换，却能够合起来确

[8] C. Guo, G. Pleiss, Y. Sun, K. Q. Weinberger, *On Calibration of Modern Neural Networks* In Proceedings of the 34th International Conference on Machine Learning, 2017, pp. 1321–1330

[9] A. N. Angelopoulos, S. Bates, *A Gentle Introduction to Conformal Prediction and Distribution-Free Uncertainty Quantification* In arXiv preprint arXiv:2107.07511, 2022

[10] D. Hendrycks, T. Dietterich, *Benchmarking Neural Network Robustness to Common Corruptions and Perturbations* In International Conference on Learning Representations, 2019

[11] P. W. Koh, S. Sagawa, H. Marklund, S. M. Xie, M. Zhang, A. Balsubramani, W. Hu, M. Yasunaga, R. L. Phillips, I. Gao, T. Lee, E. David, I. Stavness, W. Guo, B. Earnshaw, I. Haque, S. M. Beery, J. Leskovec, A. Kundaje, E. Pierson, S. Levine, C. Finn, P. Liang, *WILDS: A Benchmark of in-the-Wild Distribution Shifts* In Proceedings of the 38th International Conference on Machine Learning, 2021, pp. 5637–5664

[12] J. Cohen, E. Rosenfeld, Z. Kolter, *Certified Adversarial Robustness via Randomized Smoothing* In Proceedings of the 36th International Conference on Machine Learning, 2019, pp. 1310–1320

定失效位置和证据边界。分布外识别、领域泛化与持续适应再进一步研究变化识别、更新时机和旧版恢复。

2010 年代的算法公平研究把评价分到人群和个体。个体公平比较任务上相似者的处理，机会均等类标准在真实结果条件下比较错误或选择机会，反事实公平借因果模型研究群体属性改变后的预测[13,14,15]。技术据此测量差异、揭示指标冲突和分析干预，与伦理、法律和公共政策中的规范问题连接；哪些差异合理、哪些利益不可补偿，仍需由有权主体决定。

[13] C. Dwork, M. Hardt, T. Pitassi, O. Reingold, R. Zemel, *Fairness Through Awareness* In Proceedings of the 3rd Innovations in Theoretical Computer Science Conference, 2012

[14] M. Hardt, E. Price, N. Srebro, *Equality of Opportunity in Supervised Learning* In arXiv preprint arXiv:1610.02413, 2016

[15] M. J. Kusner, J. R. Loftus, C. Russell, R. Silva, *Counterfactual Fairness* In Advances in Neural Information Processing Systems, 2017

上述标准的证据条件也不同：群体率依赖分组与标签，个体标准依赖任务相似性，反事实标准还依赖结构因果模型及允许保留的路径。满足某个统计等式并未同时证明个体受到保护或长期分配没有扩大差距。评价必须分别记录测量、规范选择、因果假设和动态影响。

分组审计保留身份、标签与选择过程的关系，才能观察不同人经历的后果。系统决定谁进入下一环节后，过去决策还可能改变标签可见性。公平分析因此需要继续追踪数据形成、阈值分配、拒答与复核负担，以及这些决定如何改变下一轮观测，不能只报告静态差距。

样本可以估计差异，却不能自行决定应保留哪些群体、优先避免哪种错误或容许多大差异。技术分析将指标冲突、不确定性和干预后果提供给有权主体，由其在规范边界内作选择。数值证据与数值的使用权限需要同时进入记录。

当模型的计算无法直接读出时，解释研究转向局部行为、内部表示和训练来源。LIME 用局部代理，积分梯度用基准路径，SHAP 用联盟分配，分别解释预测变化[16,17,18]。评价还需区分忠实性、完整性、人的理解与实际判断收益[19]。反事实解释和算法补救则再问哪些可行行动能够改变结果，将解释与交互、因果和决策支持连接起来。

[16] M. T. Ribeiro, S. Singh, C. Guestrin, *"Why Should I Trust You?": Explaining the Predictions of Any Classifier* In arXiv preprint arXiv:1602.04938, 2016

[17] M. Sundararajan, A. Taly, Q. Yan, *Axiomatic Attribution for Deep Networks* In Proceedings of the 34th International Conference on Machine Learning, 2017, pp. 3319–3328

[18] S. Lundberg, S.-I. Lee, *A Unified Approach to Interpreting Model Predictions* In arXiv preprint arXiv:1705.07874, 2017

[19] F. Doshi-Velez, B. Kim, *Towards A Rigorous Science of Interpretable Machine Learning* In arXiv preprint arXiv:1702.08608, 2017

这些方法各自带来验收条件。局部代理需指定区域与近似误差，路径归因需说明基准和路径，联盟分配需说明特征缺失怎样处理。人员实验要检查使用者能否在真实决策中发现错误，简化任务中完成得更快并不充分。解释若用于补救，还须约束可行动变量、成本与连带后果，输入表中可以改写的数值并不一定是现实行动。

线性模型、浅层树和规则的结构常能显露部分决策逻辑，而深层网络和大型集成把计算分散到大量参数中。后验解释为局部行为、路径或贡献分配提供近似，尚未恢复完整推理。解释图因此要结合保真检验、使用者和任务评价，才能说明它是否帮助发现与纠正真实错误。

开发者定位训练和模型问题，复核者判断一次决定的证据，受影响者则需要质疑和可执行改正，三者需要的信息可能不同。先规定使用者、任务与标准，再选择解释及人因、因果可行性评价，才能把解释接入审计和补救。

数据保护又引入了另一种保证。差分隐私限制相邻数据集上输出分布的变化，约束单条数据增加的信息；成员推断与训练提取则表明模型接口也可能暴露参与事实或内容[20,21,22]。形式分析必须明确邻接关系、保护单位、随机机制和组合，在定义范围内允许任意辅助信息；经验攻击则取决于查询数、已有知识与选择策略。未被形式定义保护的对象仍可能被推断，一次攻击失败也未排除更强攻击。

训练可把记录影响留在参数中，所以删除原始记录并不等于删除训练影响。分布式参与方还可能分别观察数据、梯度、聚合和更新，重复查询也可累积攻击证据；保护范围因此需要覆盖训练、通信与发布接口。差分隐私预算按对应定理组合再次访问数据或多次数据依赖发布，对同一已发布私有结果的纯后处理或重复展示不自动追加预算。形式保证和经验攻击都须声明保护单位、组合方式、实现条件及效用代价由谁承担。

对抗样本说明，普通测试中预测正确仍可能在输入邻域内找到失败；投毒、后门和模型提取又把攻击面扩到训练材料、供应链与查询接口[23,24,25,26]。隐私研究中的统计推断与密码协议、安全研究中的威胁建模与鲁棒优化，都需要明示保护对象、观察能力和资源预算。

攻击阶段决定需要检查哪个环节：推理扰动作用于测试输入，投毒改写训练材料，后门在触发条件下激活隐藏行为，模型提取利用接口结果恢复功能或参数信息。固定脚本下防御有效，仍可能来自梯度遮蔽或评测盲区。允许攻击者根据防御调整搜索，并区分搜索失败与形式不可达，才能限定安全结论。

主动对手会观察系统并选择有利输入或时机，困难情境的出现方式因而不同于自然抽样。安全评价要记录知识、权限、查询预算和最终损害，固定攻击样本不能代表整个攻击空间。检索、插件和工具的接入还把威胁扩到供应链、权限与执行器，模型评价需要与软件安全的纵深防御和事故响应共同使用。

[20] C. Dwork, A. Roth, *The Algorithmic Foundations of Differential Privacy* In Foundations and Trends in Theoretical Computer Science, 2014, vol. 9, no. 3–4, pp. 211–407

[21] R. Shokri, M. Stronati, C. Song, V. Shmatikov, *Membership Inference Attacks against Machine Learning Models* In 2017 IEEE Symposium on Security and Privacy, 2017

[22] N. Carlini, F. Tramer, E. Wallace, M. Jagielski, A. Herbert-Voss, K. Lee, A. Roberts, T. Brown, D. Song, U. Erlingsson, A. Oprea, C. Raffel, *Extracting Training Data from Large Language Models* In 30th USENIX Security Symposium, 2021

[23] C. Szegedy, W. Zaremba, I. Sutskever, J. Bruna, D. Erhan, I. Goodfellow, R. Fergus, *Intriguing Properties of Neural Networks* In arXiv preprint arXiv:1312.6199, 2014

[24] I. J. Goodfellow, J. Shlens, C. Szegedy, *Explaining and Harnessing Adversarial Examples* In arXiv preprint arXiv:1412.6572, 2015

[25] T. Gu, B. Dolan-Gavitt, S. Garg, *BadNets: Identifying Vulnerabilities in the Machine Learning Model Supply Chain* In arXiv preprint arXiv:1708.06733, 2017

[26] F. Tramèr, F. Zhang, A. Juels, M. K. Reiter, T. Ristenpart, *Stealing Machine Learning Models via Prediction APIs* In arXiv preprint arXiv:1609.02943, 2016

开放任务中的人类反馈将行为而非固定标签作为学习对象。行为片段比较用于奖励学习，指令跟随进一步采用示范、奖励模型与策略优化[27,28]。人的判断变成可优化信号后，反馈覆盖、奖励外推和监督能力都可能成为新的误差来源：样本漏掉部署行为，策略变化使奖励外推失准，较弱监督者也可能漏看更强模型的隐蔽错误。

监督者因此不仅给答案，还比较结果、声明原则、检查过程或评价长期后果；模型优化这些代理时，可能利用协议没有预见的行为。分析需要区分能力不足、目标欠完整、监督信息不足和新情境下约束失效。对齐工作贯穿目标形成、反馈、更新、监控及执行权限，单独增加训练后过滤无法覆盖这条链。

交互还延长了后果的出现时间。单次回答的错误可能立即可见，多步计划的早期偏离却可能到数次工具调用之后才造成损害；模型也会针对监督规则调整行为。静态用例不足以代表这段过程，监督和监控本身可能被规避。任务分解、可扩展监督、过程评价和权限隔离，分别处理人无法全面理解、核验或及时阻断的困难。

数据集说明书、模型卡和风险管理框架把用途、版本、责任与生命周期保存在结果旁边[29,30,31]。这些工作为同一使用过程组织不同领域的证据：统计与优化判断性能，因果和交互判断后果与人的使用，信息安全、软件保障和治理判断运行边界。

保存来源、版本、用途、分组结果和限制，才能在环境改变后复查旧结论。文档的用途是恢复判断上下文，风险管理还要确定风险接受、监测和处置角色，以及限制权限、恢复状态和重新验收的流程。

一次发布记录还不够处理后续变化。权重、训练数据、提示、检索库、阈值和接口改变，都可能破坏原检验条件。版本追踪、变更评审、事故响应与恢复演练，使记录能够回答更新后哪些结论仍有效，并把重新验证纳入保证。

基础模型可以产生措辞不同而语义相同的答案，智能体还会检索、调用工具和改变持久状态。固定标签、单次预测、静态模型的评价范围因而需要扩展到开放语义、完整生成程序、连续交互与组件组合。分析沿数据、参数、上下文、输出和行动追踪信息，才能覆盖新的使用过程。

这一过程也连接了原本分别评价的性质：检索既提供事实证据，也可能带来注入；拒答减少错误，却可能集中等待和复核负担；解释有助审计，却也可能泄露信息或迎合检查器。需要研究证据的组合、冲突和共同失效，单独提高各项分数尚未回答系统问题。

以上路线从平均误差扩到概率和拒答，从同分布测试扩到变化与攻击，从总体指标扩到人群、个体和补救，再从静态模型扩到持续更新的系统。扩展增加了旧证据尚未覆盖的使用条件，原来的准确率等问题仍保留，只

[27] P. F. Christiano, J. Leike, T. B. Brown, M. Martic, S. Legg, D. Amodei, *Deep Reinforcement Learning from Human Preferences* In Advances in Neural Information Processing Systems 30, 2017, pp. 4299–4307

[28] L. Ouyang, J. Wu, X. Jiang, D. Almeida, C. L. Wainwright, P. Mishkin, C. Zhang, S. Agarwal, K. Slama, A. Ray, J. Schulman, J. Hilton, F. Kelton, L. Miller, M. Simens, A. Askell, P. Welinder, P. Christiano, J. Leike, R. Lowe, *Training Language Models to Follow Instructions with Human Feedback* In arXiv preprint arXiv:2203.02155, 2022

[29] T. Gebru, J. Morgenstern, B. Vecchione, J. W. Vaughan, H. Wallach, H. Daumé III, K. Crawford, *Datasheets for Datasets* In arXiv preprint arXiv:1803.09010, 2021

[30] M. Mitchell, S. Wu, A. Zaldivar, P. Barnes, L. Vasserman, B. Hutchinson, E. Spitzer, I. D. Raji, T. Gebru, *Model Cards for Model Reporting* In Proceedings of the Conference on Fairness, Accountability, and Transparency, 2019

[31] National Institute of Standards and Technology, *Artificial Intelligence Risk Management Framework (AI RMF 1.0)*, tech. rep. NIST AI 100-1, National Institute of Standards and Technology, 2023

需连同行动损失、承担者、威胁和生命周期解释。下一小节集中研究这些联系中尚缺的证据。

### 10.6.2 当前前沿

图 10.4按三层组织“系统何时可以被依赖”的研究。第一层分成要求与影响、证据与行为、防护与治理；第二层分别展开要求操作化、未知识别与转交、风险收益与负担分配、变化适应与恢复、解释审计与补救、目标监督与权限、隐私安全与行动保护、联合保证与持续验证八个问题。第三层为其中五项列出代表课题，未列示例的问题并不表示已经解决。下面五组方向跨越这些问题，并不与第二层逐一对应。

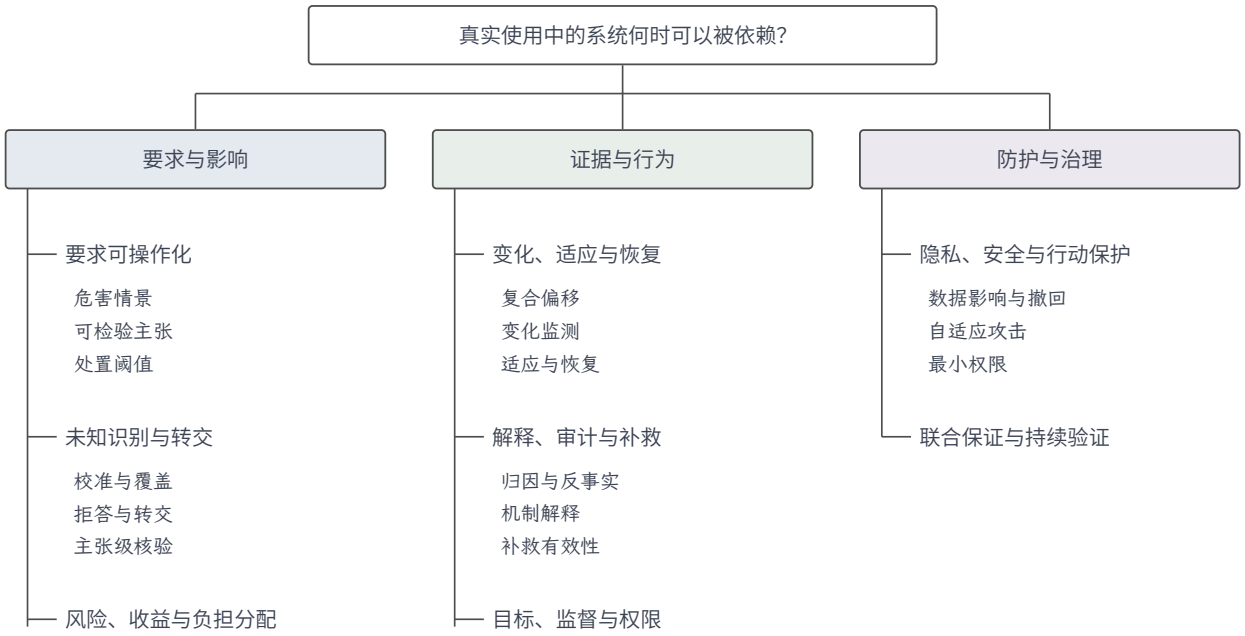


图 10.4　研究地图由使用问题向下展开：三组判断领域连接八项问题，其中五项列出危害情境、覆盖、复合偏移、机制解释、自适应攻击等十五项课题。连接线表示领域、问题和课题的组织层次，排列不表示因果或先后顺序。其余三个问题仅是未列示例。

**开放任务的要求表达与可靠性控制**　开放生成与智能体任务需要评价事实主张、检索依据、工具调用、交互轨迹和状态变化，单个标签已不能覆盖这些对象。行为测试将预期转为用例，并利用失败发现遗漏[32]。但用例仍限于已经识别的情境。自动扩充数量若只改变表面形式，也不会补齐语义、权限或长期后果的边界。

可靠性于是要从整段得分追踪到单条主张、证据来源与行动风险。生成任务的共形扩展仍需先定义校准单元、覆盖对象、错误事件、集合构造与可交换等条件，才能解释其覆盖；覆盖本身没有核验事实[33,34]。**语义熵**（semantic entropy）把含义相近的不同措辞合并，计算重复生成在语义上的分歧[35]。两者衡量的对象不同，也都会遇到稳定复述同一错误、检索或筛选改变分布、生成器与验证器共享盲点等困难。

拒答、集合和人工转交将这些信号变成行动，却同时改变覆盖率、延迟和群体负担。研究需要把自动处理风险、拒答分布、备选流程容量及多轮选择的风险累积合起来约束。“不知道”的处置只有可以执行和复核、又没有简单把风险转给人工或特定人群，才支持使用判断。

**组合变化与长期分配后果**　现实部署往往同时改变设备、语言、人群、时间与策略，单因素扰动无法说明相互作用。跨来源数据展示复合偏移中的性能差异；脑电图（electroencephalography, EEG）基础模型的一项研究比较多个预训练模型、下游任务和数据集上的测试时适应，发现所评估方法的改变量不一致，梯度方法尤其可能明显下降[36,37]。标签延迟或缺失时，研究还需判断观测外观改变是否已经影响风险，以及哪些原证据继续有效。

风险变化也改变人的经历：错误、等待和复核可能重新分配。机会均等与反事实标准使用不同标签和因果条件[38,39]。资源分配、拒绝与推荐又会改变下一轮可见数据。干预后群体差距受模型、行为响应和资源限制共同影响，静态差距因而不足以代表长期效果。

联合评价可以使用预设时间窗口，除平均风险外，记录风险最高或约束余量最低的时段、恢复到阈值的时间和更新后既有任务的回归结果。拒答、主动标注和人工处理负担也需按承担者记录。这样的时间轴把鲁棒性、公平性和服务流程连起来，检查收益是否将风险转移到别的环境、人群或测量范围之外。

[32] M. T. Ribeiro, T. Wu, C. Guestrin, S. Singh, *Beyond Accuracy: Behavioral Testing of NLP Models with CheckList* In Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics, 2020, pp. 4902–4912

[33] A. N. Angelopoulos, S. Bates, *A Gentle Introduction to Conformal Prediction and Distribution-Free Uncertainty Quantification* In arXiv preprint arXiv:2107.07511, 2022

[34] G. Loaiza-Ganem, K. Zhang, W. Cui, M. T. Law, K. K. Leung, *Conf-Gen: Conformal Uncertainty Quantification for Generative Models* In Proceedings of the 43rd International Conference on Machine Learning, 2026, pp. 80383–80412

[35] S. Farquhar, J. Kossen, L. Kuhn, Y. Gal, *Detecting Hallucinations in Large Language Models Using Semantic Entropy* In Nature, 2024, vol. 630, pp. 625–630

[36] P. W. Koh, S. Sagawa, H. Marklund, S. M. Xie, M. Zhang, A. Balsubramani, W. Hu, M. Yasunaga, R. L. Phillips, I. Gao, T. Lee, E. David, I. Stavness, W. Guo, B. Earnshaw, I. Haque, S. M. Beery, J. Leskovec, A. Kundaje, E. Pierson, S. Levine, C. Finn, P. Liang, *WILDS: A Benchmark of in-the-Wild Distribution Shifts* In Proceedings of the 38th International Conference on Machine Learning, 2021, pp. 5637–5664

[37] G. J. Lee, J. Pradeepkumar, J. Sun, *Test-Time Adaptation for EEG Foundation Models: A Systematic Study under Real-World Distribution Shifts* In Proceedings of the 11th Machine Learning for Healthcare Conference, 2026, pp. 948–984

[38] M. Hardt, E. Price, N. Srebro, *Equality of Opportunity in Supervised Learning* In arXiv preprint arXiv:1610.02413, 2016

**可扩展监督、机制解释与审计** 任务变长或变复杂后，人的示范、偏好与原则未必覆盖策略访问的行为，奖励模型可能外推失准，评价者也可能共有盲点[40,41]。任务分解、过程反馈和弱到强监督试图扩大可用信息；较弱监督者仍可能看不出隐蔽错误，过程记录也可能偏离实际计算。这是扩大监督时需要同时保留的边界。

**可监控性**（monitorability）把监督困难写成可检验问题：在声明观察通道与监控能力下，能否以预设漏报、误报或发现概率识别行为、权限偏离[42,43]。参与优化的监控器可能被规避，共享数据、架构或提示的检查者也可能相关出错。因此需要研究独立监督、随机审计、保留验收任务和抗规避监控，而不只测静态准确率。

稀疏特征分解等机制解释为内部状态提供观察入口[44]。一个方向能够命名，还未说明任务计算因果依赖它；模型证据也要接到工具轨迹、权限与状态变化。只有支持发现错误、定位干预或实际补救的解释，才为可信使用增加了证据。

**隐私、安全与智能体行动** 隐私评价沿数据、参数、输出和参与方追踪信息。差分隐私约束保护单位对输出分布的额外影响，成员推断和训练提取检验接口泄露[45,46]。前者需要保护单位、机制及数据访问和发布的组合，固定私有输出的纯后处理不自动新增预算；后者需要外部知识、查询数和选择策略。两者还要检查原件、参数、检索索引、缓存和审计副本中的信息残留，一次经验攻击失败并不能代替形式保证。

检索、长期记忆与工具使外部数据也可能影响控制。间接提示注入通过检索内容改变系统行为[47]。来源签名只能确认身份，不能保证内容安全；输入过滤也没有落实执行端类型、权限和预算。威胁模型要覆盖供应链、接口与执行器，并允许对手依据防御反馈调整策略。

工具执行使损害进入持久状态。动态评测同时考察正常任务、有用第三方指令与恶意操纵，以测量安全和过度防御的取舍[48]。评价应区分文字改变、调用形成、实际执行及状态可恢复性，并检查突破后的恢复。自适应攻击、多组件供应链与端到端损害评估由此成为研究对象，防护仍需保留正常任务的可用性。

[39] M. J. Kusner, J. R. Loftus, C. Russell, R. Silva, *Counterfactual Fairness* In Advances in Neural Information Processing Systems, 2017

[40] P. F. Christiano, J. Leike, T. B. Brown, M. Martic, S. Legg, D. Amodei, *Deep Reinforcement Learning from Human Preferences* In Advances in Neural Information Processing Systems 30, 2017, pp. 4299–4307

[41] L. Ouyang, J. Wu, X. Jiang, D. Almeida, C. L. Wainwright, P. Mishkin, C. Zhang, S. Agarwal, K. Slama, A. Ray, J. Schulman, J. Hilton, F. Kelton, L. Miller, M. Simens, A. Askell, P. Welinder, P. Christiano, J. Leike, R. Lowe, *Training Language Models to Follow Instructions with Human Feedback* In arXiv preprint arXiv:2203.02155, 2022

[42] C. Burns, P. Izmailov, J. H. Kirchner, B. Baker, L. Gao, L. Aschenbrenner, Y. Chen, A. Ecoffet, M. Joglekar, J. Leike, I. Sutskever, J. Wu, *Weak-to-Strong Generalization: Eliciting Strong Capabilities With Weak Supervision* In arXiv preprint arXiv:2312.09390, 2023

[43] M. Y. Guan, M. Wang, M. Carroll, Z. Dou, A. Y. Wei, M. Williams, B. Arnav, J. Huizinga, I. D. Kivlichan, A. Glaese, J. Pachocki, B. Baker, *Monitoring Monitorability* In Proceedings of the 43rd International Conference on Machine Learning, 2026, pp. 37538–37602

**联合保证与持续验证** 组件组合需要新的保证：检索器可能交出敏感信息，生成器可能给出正确调用却使用过大权限，低错误率组件也可能在同一输入上同时失败。保证案例与结构化证据图可以追踪主张在接口间的传递，但错误相关性与要求冲突仍需显式分析。简单加总、相乘或加权，会漏掉依赖和不可补偿约束。

持续使用还要连接记录与真实版本。说明书、模型卡和风险框架保存来源、用途、分组结果、限制及责任[49,50,51]。若记录未接入监测和变更流程，更新后便无法复核。权重、提示、检索、阈值、权限或人工流程任一变化，都可能要求重新判断证据。

为主张设期限与触发条件，再用线上监测、分阶段开放、回归检查和恢复演练控制变化，可以把保证维持在运行过程中。标签延迟、严重低频事件、版本并存与监测器失效仍是困难。研究要维护的是明确范围、可复核证据以及可发现、可处置的失效条件，永久标签无法承担这项职责。

## 10.7 本章小结

回到章首，97% 准确率尚不能支持永久删除。要求层先限定自动处理范围、错误分母与不可补偿条件，证据层再说明独立样本、压力用例和机制检查支持了什么，生命周期层确定停用、恢复和风险接受职责。邮件实例据此只允许有条件的可恢复隔离。其 2% 阈值约束隔离邮件中的正常比例，区别于全部正常邮件的误隔离率和全部垃圾邮件的漏放率；三种分母分别保存了阈值与置信上界。

对预测与拒答的证据归入可靠性，对变化后有效性的证据归入鲁棒性，对机会、错误和负担的证据归入公平性。行为边界、理解与质疑、信息保护和主动攻击则分别由对齐、可解释性、隐私与安全补充。它们可以支持同一次使用判断，但一项改进没有替其他要求提供证明。

基础模型和智能体将这种判断扩到开放生成、多次调用和完整行动链。已有理论界、测试和干预分别解决了局部问题，组合变化、监督不足、自适应攻击与版本过期仍会破坏证据联系。评价需要沿使用过程保留这些剩余条件。

技术可信性因此形成一组带范围、证据和处置条件的主张。主张说明系统何时达到要求、哪里仍有不确定性，供审批和复查使用；职责安排、法律判断以及受影响者参与的治理决定，还需由相应主体作出。

**延伸阅读** 继续阅读 NIST 人工智能风险管理框架时，可以沿本章情境把测量、风险处置、责任与触发条件对应起来，使框架中的原则转为具体记录[52]。

[44] T. Bricken, A. Templeton, J. Batson, B. Chen, A. Jermyn, T. Conerly, N. Turner, C. Anil, C. Denison, A. Askell, R. Lasenby, Y. Wu, S. Kravec, N. Schiefer, T. Maxwell, N. Joseph, Z. Hatfield-Dodds, A. Tamkin, K. Nguyen, B. McLean, J. E. Burke, T. Hume, S. Carter, T. Henighan, C. Olah, *Towards Monosemanticity: Decomposing Language Models With Dictionary Learning* In Transformer Circuits Thread, 2023

[45] C. Dwork, A. Roth, *The Algorithmic Foundations of Differential Privacy* In Foundations and Trends in Theoretical Computer Science, 2014, vol. 9, no. 3–4, pp. 211–407

[46] N. Carlini, F. Tramer, E. Wallace, M. Jagielski, A. Herbert-Voss, K. Lee, A. Roberts, T. Brown, D. Song, U. Erlingsson, A. Oprea, C. Raffel, *Extracting Training Data from Large Language Models* In 30th USENIX Security Symposium, 2021

[47] K. Greshake, S. Abdelnabi, S. Mishra, C. Endres, T. Holz, M. Fritz, *Not What You've Signed Up For: Compromising Real-World LLM-Integrated Applications with Indirect Prompt Injection* In arXiv preprint arXiv:2302.12173, 2023

[48] H. Li, R. Wen, S. Shi, N. Zhang, Y. Vorobeychik, C. Xiao, *AgentDyn: Are Your Agent Security Defenses Deployable in Real-World Dynamic Environments?* In arXiv preprint arXiv:2602.03117, 2026

[49] T. Gebru, J. Morgenstern, B. Vecchione, J. W. Vaughan, H. Wallach, H. Daumé III, K. Crawford, *Datasheets for Datasets* In arXiv preprint arXiv:1803.09010, 2021

[50] M. Mitchell, S. Wu, A. Zaldivar, P. Barnes, L. Vasserman, B. Hutchinson, E. Spitzer, I. D. Raji, T. Gebru, *Model Cards for Model Reporting* In Proceedings of the Conference on Fairness, Accountability, and Transparency, 2019

数据集说明书与模型卡分别补充数据的动机、组成、采集条件，以及模型用途和分组评价。二者有助于限定记录的证据范围，仍要由实际测试支持其中的主张[53,54]。

[51] National Institute of Standards and Technology, *Artificial Intelligence Risk Management Framework (AI RMF 1.0)*, tech. rep. NIST AI 100-1, National Institute of Standards and Technology, 2023

[52] National Institute of Standards and Technology, *Artificial Intelligence Risk Management Framework (AI RMF 1.0)*, tech. rep. NIST AI 100-1, National Institute of Standards and Technology, 2023

[53] T. Gebru, J. Morgenstern, B. Vecchione, J. W. Vaughan, H. Wallach, H. Daumé III, K. Crawford, *Datasheets for Datasets* In arXiv preprint arXiv:1803.09010, 2021

[54] M. Mitchell, S. Wu, A. Zaldivar, P. Barnes, L. Vasserman, B. Hutchinson, E. Spitzer, I. D. Raji, T. Gebru, *Model Cards for Model Reporting* In Proceedings of the Conference on Fairness, Accountability, and Transparency, 2019

第 11 章

# 可靠性

邮件系统准备按照“垃圾邮件概率 0.9”自动隔离一封邮件。要判断这次用法，我们先得知道 0.9 描述哪个事件：它是否意味着报告同类概率的邮件中约九成为垃圾邮件，还是仅为模型的高分？生成回答中高概率的词元也有类似问题，它表示模型倾向生成该词，并未直接说明内容真实。本章从输出的对象开始，建立检验和使用不确定性的依据。

**可靠性**（reliability）要求在约定条件下，预测及据此采取的决策满足明确的质量和风险标准。概率要求可以约束报告数值与事件频率，范围要求可以约束覆盖，行动要求则可以约束自动处理损失。一条主张需写出模型输出或完整程序、失效事件、指标方向、目标水平、总体、时间范围以及抽样或反馈条件。若带统计保证，还要指出概率针对的随机对象，才能复核其含义。

第 10章的三个层次在这里分别对应标准、支持和持续使用条件。概率、范围或决策标准属于要求层，校准、覆盖与风险检验提供证据，模型版本、阈值、抽样或反馈改变则触发复验与使用限制。后两层使可靠性主张能够随系统运行继续接受检查。

模型给出的分布、区间和分歧提示尚未确定的结果，但这些提示也可能错误。我们先在第 11.1节解释它们估计了什么，再在第 11.2节以独立结果检查数值、决策用途与适用范围。得到检验对象后，第 11.3节构造覆盖或风险受控的程序，并限定保证所需条件。这条顺序把估计、证据与使用承诺连起来。

图 11.1先固定邮件处置：规则接受的判断用于自动隔离，尚需辨别的判断转复核。图中的线索不是垃圾邮件定义，含宣传内容也不能直接决定类别。分流是否减少损失，需要连同处理量一起检验，见第 11.2.2节。

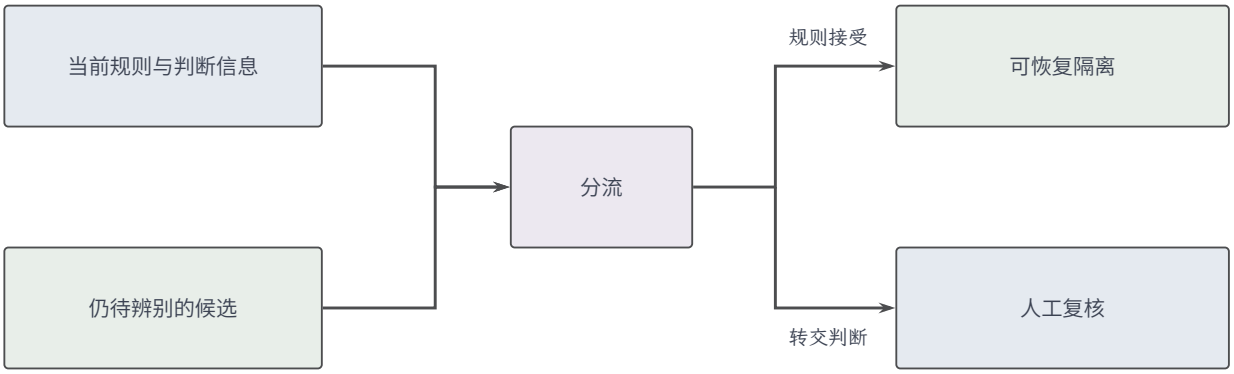


图 11.1 邮件按当前规则的判断依据进入自动隔离或复核。规则接受的判断进入可恢复隔离，仍待辨别的候选转人工接管。分流尚未证明可靠，人工也未假定无误；图 11.4继续按处理比例和接受风险计数。

## 11.1 不确定性的来源与估计

邮件系统可能要求概率具有频率含义、预测范围覆盖结果，或自动行动的风险低于阈值。要满足其中一项，我们先需要表达尚未确定的结果。不确定性估计提供这样的表达，至于表达是否正确，还需后续证据。

尚不能确定结果有两种不同原因：输入遗漏了决定结果的信息，或者相关训练数据不足以约束预测规律。前者研究同一输入下结果的波动，后者研究仍与数据相容的候选模型及其分歧。本节建立两类估计对象，下一节再用独立数据检查估计是否兑现其含义。

### 11.1.1 不确定性的来源

设当前观测为 $\boldsymbol{x}$，目标为 $y$，训练资料为 $\mathcal{D}$。邮件文本相同而发送意图不同，说明固定观测仍可能对应不同结果。相对于这份观测，剩余的条件随机性称为**偶然不确定性**（aleatoric uncertainty）。若加入能够区别意图的信息，这一随机性可能减少；“偶然”因此不意味着无论获得什么信息都无法减少。

有限训练资料还有另一种缺口。样本只约束已观察情形，给定模型假设与拟合判据后，多个规律可能都未被排除，却在数据稀少的区域产生不同预测。这些模型“与数据相容”的判据要由具体方法给出，例如后验支持或集成构造。新增相关标签可能缩小其分歧，所表达的知识不足称为**认知不确定性**（epistemic uncertainty）。一次预测分数无法唯一拆出这两种来源，拆分仍相对于观测和模型假设。

两类缺口对应不同的补充信息。对相同文字中的不同意图，仅增加同类记录未必能唯一判断，需要增加区分结果的观测；对训练样本稀少的新语

言，增加有标签邮件则可能约束候选规律。前者要表达给定信息下的结果分布，后者要表达对规律的把握程度，这也决定了下面两种估计的用途。

这种对象区分并没有使真实大小变成已知量。条件分布通常未知，模型也可能遗漏因素，参数后验、集成和条件分布学习得到的都是假设下的估计。它们是计算手段，近似造成的估计误差还要与被估计的不确定性分别说明。

图 11.2保持邮件任务不变，把缺少意图特征与缺少相关训练样本并排画出。新增同类样本可减少模型知识不足，却不会自动提供原来没有观测的意图特征。

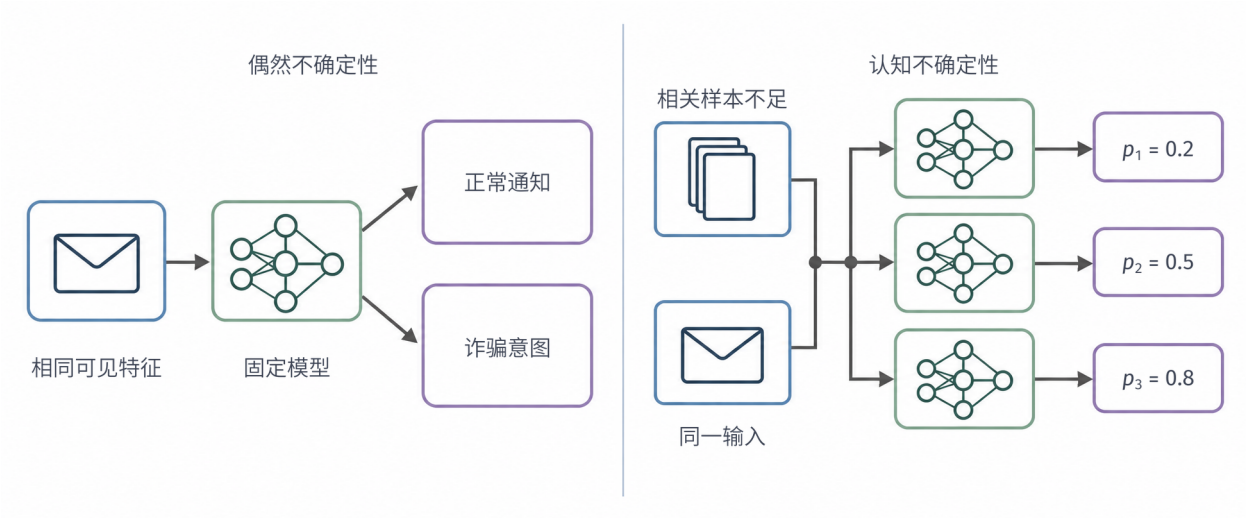


图 11.2 固定观测后比较两类缺口：左侧相同特征对应通知或诈骗意图，模型需表达结果分布；右侧相关样本少，三个候选预测不同，$p_m$ 表示 $p_m(y = 1 \mid \boldsymbol{x})$。0.2、0.5、0.8 是示意分歧的构造概率，并非实测或后验抽样。两类来源都依当前观测及模型假设定义。

### 11.1.2 认知不确定性的估计

只保留一个拟合模型，看不见数据还容许哪些规律。我们可以保留多个候选，比较它们对同一输入的预测，从而表达认知不确定性。比较对象要放在预测上：参数差距很大，仍可能产生相同输出，参数分散并不等于决策分歧。

贝叶斯方法用参数后验给候选规律分配权重。以下采用给定协变量 $\boldsymbol{x}$ 的条件模型，假设给定参数后未来目标与训练资料 $\mathcal{D}$ 条件独立，并使用相应的概率质量函数或密度。记参数为 $\theta$、后验密度为 $p(\theta \mid \mathcal{D})$，对每个参数的条件预测取后验平均，得到

$$p(y \mid \boldsymbol{x}, \mathcal{D}) = \int p(y \mid \boldsymbol{x}, \theta) p(\theta \mid \mathcal{D}) \, \mathrm{d}\theta. \tag{11.1}$$

这个积分汇合了模型内部的结果波动与模型之间的差别。对二阶矩存在的实值目标，用全方差公式可将两者分开：

$$\begin{aligned}\operatorname{Var}(y \mid \boldsymbol{x}, \mathcal{D}) = {} & \mathbb{E}_{\theta \mid \mathcal{D}} \operatorname{Var}(y \mid \boldsymbol{x}, \theta) \\ & + \operatorname{Var}_{\theta \mid \mathcal{D}} \mathbb{E}(y \mid \boldsymbol{x}, \theta).\end{aligned} \tag{11.2}$$

第一项平均每个模型的条件方差，第二项计算模型预测均值的后验分歧，分别对应所建模型的偶然波动和参数知识不足。分解成立于这套概率模型，尚未证明现实因素全部被涵盖；候选模型如果共同遗漏因素，均值分歧很小仍可能系统性出错（可参考第一卷“随机变量”章的“预测分布的计算与评价”小节及其中的后验预测计算）。

式 (11.1)的后验预测确定了平均对象，计算却可能困难：深度网络参数多，积分通常不能直接求出。只选后验密度最高的一组参数会丢掉其他候选的贡献，我们需要在预算内近似保留这些贡献。

一种近似是选择易抽样的分布族 $q_{\boldsymbol{\phi}}(\theta)$，让参数 $\boldsymbol{\phi}$ 调节它与后验的差异。设 $p(\mathcal{D} \mid \theta)$ 为似然、$p(\theta)$ 为先验，并假设证据 $0 < p(\mathcal{D}) < \infty$。以下候选 $q_{\boldsymbol{\phi}}$ 对后验绝对连续，后验 KL 有限；为将目标拆成两项，还要求 $\mathbb{E}_{q_{\boldsymbol{\phi}}} |\log p(\mathcal{D} \mid \theta)| < \infty$ 与先验 KL 有限。在这些条件下，以 KL 散度比较近似和后验，可等价最小化目标

$$\mathcal{J}(\boldsymbol{\phi}) = -\mathbb{E}_{q_{\boldsymbol{\phi}}} \log p(\mathcal{D} \mid \theta) + \operatorname{KL}\big(q_{\boldsymbol{\phi}}(\theta) \,\|\, p(\theta)\big). \tag{11.3}$$

记此目标为 $\mathcal{J}(\boldsymbol{\phi})$，因为 $\operatorname{KL}(q_{\boldsymbol{\phi}}(\theta) \| p(\theta \mid \mathcal{D})) = \mathcal{J}(\boldsymbol{\phi}) + \log p(\mathcal{D})$，与 $\boldsymbol{\phi}$ 无关的证据项不影响优化（可参考第一卷“概率分布”章的“表示约束下的分布逼近”一节）。似然项要求候选解释数据，KL 项约束偏离先验。优化替代了直接积分，却无法突破近似族本身的限制，例如独立单峰分布未必容纳相距很远的多种解释；收敛也不消除这一限制。

Gal 和 Ghahramani 据此解释特定设置中的 dropout，并在预测时保留随机失活，多次前向计算后汇合预测。**蒙特卡洛失活**（Monte Carlo dropout，MC dropout）用不同掩码生成候选预测，近似后验平均。方法复用了训练中的失活机制，但其贝叶斯含义依赖近似模型与正则化；任意已有网络开启 dropout 所产生的波动不能自动视为正确后验[1]。

若 $M$ 次计算分别输出类别分布 $p_m(y \mid \boldsymbol{x})$，我们用 $\bar{p}(y \mid \boldsymbol{x}) = M^{-1} \sum_{m=1}^{M} p_m(y \mid \boldsymbol{x})$ 近似预测分布。增大 $M$ 只减少既定近似下的蒙特卡洛误差，不会修复先验、似然或近似族。对低延迟服务，还需比较重复计算的成本与拒答所减少的损失。

也可以直接独立优化多个模型，不显式拟合参数后验。**深度集成**（deep ensembles）汇合多个网络的预测分布，把成员间分歧补入单个网络的输

[1] Y. Gal, Z. Ghahramani, *Dropout as a Bayesian Approximation: Representing Model Uncertainty in Deep Learning* In Proceedings of the 33rd International Conference on Machine Learning, 2016, pp. 1050–1059

出。Lakshminarayanan 等采用独立初始化、概率评分训练和集成预测，给出了能够并行训练的不确定性基线[2]。

以回归为例，成员 $m$ 输出均值 $\mu_m(\boldsymbol{x})$ 和方差 $v_m(\boldsymbol{x})$。为同时保留内部波动与成员分歧，等权混合使用全方差分解：

$$\begin{aligned}\bar{\mu}(\boldsymbol{x}) &= \frac{1}{M}\sum_{m=1}^{M}\mu_m(\boldsymbol{x}),\\ \bar{v}(\boldsymbol{x}) &= \frac{1}{M}\sum_{m=1}^{M}v_m(\boldsymbol{x}) + \frac{1}{M}\sum_{m=1}^{M}\big(\mu_m(\boldsymbol{x})-\bar{\mu}(\boldsymbol{x})\big)^2.\end{aligned} \tag{11.4}$$

两个教学成员的均值取 0 和 2、方差都为 1，混合均值为 1，方差为 $1+1=2$。只平均成员方差会遗漏均值差别，只计算均值差别又会遗漏内部波动；公式中的两项共同构成混合方差。

独立初始化只是训练的随机来源，不保证成员在真实数据上独立出错。共同数据、架构和损失可能造成共同盲点，一致答错时分歧也很小。MC dropout 和深度集成的价值因此仍要通过校准、拒答及变化条件下的独立检验确认。

### 11.1.3 偶然不确定性的刻画

前面通过改变候选模型观察规律分歧，现在固定一个候选，研究同一输入还会出现哪些结果。这是式 (11.2)第一项的内部波动。分类可输出类别分布，回归可学习条件分布、随输入变化的均值和方差；若任务只需区间，则可直接拟合所需分位点。

我们先用一个分布假设计算训练损失。若 $y \mid \boldsymbol{x}$ 为均值 $\mu(\boldsymbol{x})$、正方差 $v(\boldsymbol{x})$ 的正态分布，省略常数的单样本负对数似然是

$$\frac{(y-\mu(\boldsymbol{x}))^2}{2v(\boldsymbol{x})} + \frac{1}{2}\log v(\boldsymbol{x}).$$

大残差可通过增大方差降低第一项，却同时增加对数项，所以模型不能无代价地无限放大方差。不过正态假设仍限制结果形状：相似邮件若进入快速核验或深入调查，处理时长可能双峰；一个中间均值与大方差未必为处置提供足够信息。

若任务只需要某个分位点，我们可以避免指定完整分布。对 $\tau \in (0,1)$，用残差 $u = y - q_\tau(\boldsymbol{x})$ 构造**分位数损失**（pinball loss）：

$$\rho_\tau(u) = u\big(\tau - \mathbb{I}\{u<0\}\big), \qquad u = y - q_\tau(\boldsymbol{x}).$$

在期望存在时，最小化真实分布下的期望损失得到一个 $\tau$ 分位点，即目标不大于它的概率至少 $\tau$，不小于它的概率至少 $1-\tau$。高分位对低估更重罚，

[2] B. Lakshminarayanan, A. Pritzel, C. Blundell, *Simple and Scalable Predictive Uncertainty Estimation using Deep Ensembles* In Advances in Neural Information Processing Systems, 2017

低分位对高估更重罚，由此可分别学上下界。有限数据、模型及求解误差仍可能使覆盖偏离目标，需要独立校准。

方差和分位点本身也是学到的量，其估计受知识不足影响，不能把网络输出的方差认定为真实偶然不确定性。多个模型的结果分布混合后，范围同时含内部波动和候选分歧，仍应在未用于拟合的数据上检查。预测区间保护未来目标，参数置信或可信区间保护参数；仅传播参数区间未必包含结果噪声。

生成模型还改变了概率的对象。回答词元序列 $(w_1, \ldots, w_T)$ 的概率是逐步条件概率的乘积，表示模型生成这段措辞的倾向，而非陈述真实的概率。同一语义可有多种措辞，因此先确定评价单元是事实主张、完整答案还是任务结果，再选择评分。

要检验事实风险，我们需要冻结整个生成程序：版本、提示、检索、采样、重试、筛选和核验器。若事件为“每项事实主张均得到指定来源支持”，先规定主张切分、合格来源与分歧裁决，再用未参与这些设定的数据估计风险。评判者的漏报和误报是测量误差，应单独检查。

这套程序也可给语义不确定性或拒答分数。按第 11.2.2节固定阈值后，报告自动回答的事实错误、处理比例及转人工成本。这样才检验了章首生成问题；低词元熵、低语义分歧或高评判分数本身，都要通过对应事件核验，不能直接当事实正确。

## 11.2 可靠性的检验

已有概率、区间和分歧分数之后，独立结果提供了检验对象。我们先检查报告数值：例如所有报告 0.9 的事件，在总体中是否约有九成发生。

除了检查报告数值是否得到支持，还要观察它是否识别易错输入。能排序出较高损失的预测，拒答才可能降低自动处理风险，这与概率数值准确是不同的要求。

如果只对全体取平均，两种检验都可能遗漏重要语言或使用条件。第三步是在原范围内做局部复测，检查前面证据对谁成立；它扩展证据的条件化范围，并未定义新的综合分数。

各项检验需在模型拟合、概率修正与阈值选择结束后进行。测试结果反复参与选择会破坏独立性。生成任务还要固定事件、评判者和采样，区分来源存在、来源支持与现实正确，字符串一致不能涵盖这些判断。诊断可以展示样本差异，达标结论则还需抽样条件和估计误差。

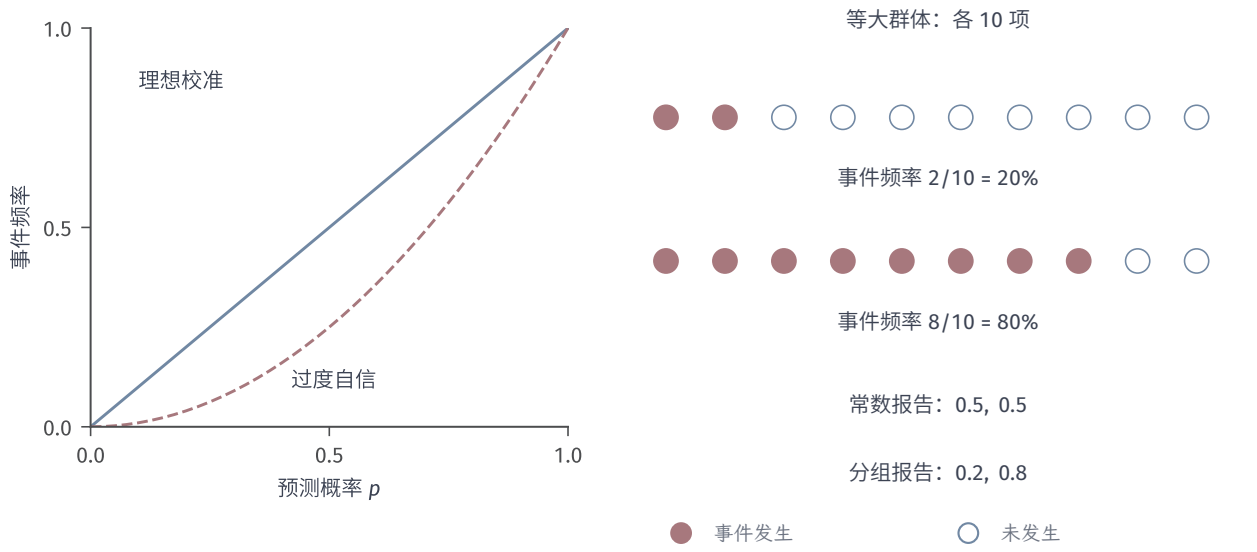


图 11.3 左侧用实线理想关系和虚线过度自信关系示意校准，两者均非实验。右侧构造等大群体，事件频率 20% 和 80%；常数 0.5 总体校准，分组 0.2 与 0.8 也校准，后者同时提供组间区分。

### 11.2.1 概率与预测范围的检验

模型给出很集中的范围，范围仍可能放错位置；覆盖所有标签的集合又能恒覆盖，却不能帮助选行动。因此，在检查覆盖或概率承诺之外，还应按用途评价范围提供的信息。仅承诺边际覆盖时，大小是效率而非覆盖成立的前提。

邮件的 0.9 需要对照哪些结果？二分类中记 $y \in \{0,1\}$，$p(\boldsymbol{x})$ 报告 $y=1$ 的概率，我们检查同一分数下的事件均值：

$$\mathbb{E}[y \mid p(\boldsymbol{x})] = p(\boldsymbol{x}) \quad \text{相对于当前联合分布几乎必然成立,} \tag{11.5}$$

**校准**（calibration）于是要求，相同概率报告在总体中有相符的事件频率。条件期望形式也适用于连续分数，避免对概率为零的精确分数集合直接计算普通频率（可参考第一卷“随机变量”章的“二元概率校准”定义）。

始终报告总体正例比例就可能校准，但无法区分输入。校准和区分能力因此要分别评价，平均覆盖、个体信息量与行动损失也不能互相代替。Guo 等的神经网络研究同样表明，分类表现较好不自动意味着概率表达恰当[3]。

图 11.3固定群体频率，比较常数与分组报告。两种报告都可以校准，只有后者区分了不同风险。

[3] C. Guo, G. Pleiss, Y. Sun, K. Q. Weinberger, *On Calibration of Modern Neural Networks* In Proceedings of the 34th International Conference on Machine Learning, 2017, pp. 1321–1330

**概率校准的经验修正** 若类别预测已达到要求，但独立校准数据表明概率系统性偏大，我们可以只调整概率表达。温度缩放用一个正参数 $t$ 缩放未归一化类别对数分数 $z_k(\boldsymbol{x})$（logit），再归一化：

$$p_t(y = k \mid \boldsymbol{x}) = \frac{\exp(z_k(\boldsymbol{x})/t)}{\sum_j \exp(z_j(\boldsymbol{x})/t)}.$$

$t$ 由校准集负对数损失选择。正温度保留同一输入的类别排序及最大概率类别，却改变集中程度；隔离或拒答若用固定概率阈值，行动仍会变化，需重新检查第 10.1节的损失。校准数据支持的修正并未提供任意新分布保证。

$t > 1$ 缩小分数差并使分布平缓，$0 < t < 1$ 则使分布集中。单参数降低小样本拟合难度，也限制可修偏差；各类别偏差方向不同时，单温度可能不足。类别相关变换或单调映射可更灵活，却增加估计难度，甚至改变决策边界。复杂度要经独立检验选择，校准集损失不足以决定。

修正后仍需重新检查输出兑现了什么。概率比较事件频率并评分整份分布，集合或区间比较名义与实际覆盖并报告宽度。这些检查支持输出含义，下一小节才检查输出筛选输入的决策作用。

有限样本难以逐一观察连续概率，可以预设区间形成可靠性图。对非空区间 $b$，记样本数 $n_b$、平均预测 $\bar{p}_b$、正例比例 $\bar{y}_b$，用差值的绝对值计算分箱误差，再按样本占比加权：

$$\widehat{\mathrm{ECE}} = \sum_{b=1}^{B} \frac{n_b}{n} |\bar{p}_b - \bar{y}_b|. \tag{11.6}$$

$B$ 是区间数，$n$ 是总样本数。粗分箱可能抵消相反偏差，细分箱则增加频率波动，ECE 必须连同分箱口径和样本量报告，不同口径不能直接排序。

概率还可用负对数损失与 Brier 分数评价。二分类 Brier 经验分数为 $n^{-1}\sum_i (p(\boldsymbol{x}_i) - y_i)^2$。为说明其最小化对象，固定输入，记真实条件概率为 $\eta(\boldsymbol{x})$，展开期望可得

$$\mathbb{E}[(p - y)^2 \mid \boldsymbol{x}] = (p - \eta)^2 + \eta(1 - \eta).$$

与 $p$ 有关的项仅为 $(p - \eta)^2$，故期望最小点是真实概率。样本评分仍同时反映校准与区分，不能替代分组诊断。

这种在真实分布处最优的评分称为**适当评分规则**（proper scoring rule），最优分布唯一时称严格适当。类别向量 $\boldsymbol{p}$ 的负对数损失期望等于真实熵加真实分布到 $\boldsymbol{p}$ 的 KL 散度，因此把会发生的事件报告得极不可能会付出较大代价。Brier 有界，惩罚极端错误较温和。二者评价概率质量，仍不等于误拦重要邮件的行动损失。

多类别时，需要声明校准条件。最大概率与正确率的比较只检验最高分预测；逐类别比较检验每类概率与标签频率；完整向量校准则要求同一向量下所有类别比例都吻合。后者要求更强、数据更多。仅看最高分会漏掉其余类别的偏差，而这些偏差可能影响代价决策和集合构造。

可靠性图还应展示每个区间的样本支持。构造例中，一个区间只有 10 封邮件，平均报告 0.9 且其中 9 封为垃圾邮件，不能精确确认总体概率 0.9。预设分箱、增加资料并报告二项区间，才能显示 9/10 背后的估计不确定性。观察结果后反复合并不利区间会改变评价过程。

集合 $C(\boldsymbol{x})$ 的覆盖用 $\mathbf{1}\{y \in C(\boldsymbol{x})\}$ 的样本均值估计，同时报告大小，回归区间则报告长度。某批样本达到 90% 覆盖，只是 90% 承诺的经验支持，仍需抽样误差；总体达到也不能代替各群体或各输入类别的覆盖。

**示例 11.1　校准与区分能力**　构造一个正例比例 10% 的总体。甲始终报告 0.1，在总体上校准；乙把样本分成占比 5/6 和 1/6 的两组，各报告与组内频率相符的 0.02 和 0.5。两组总正例比例为 $(5/6)\times 0.02 + (1/6)\times 0.5 = 0.1$，所以乙也校准，却区分了风险。若要筛选高风险输入，我们还需评价这项区分，校准误差小本身无法完成选择。

### 11.2.2 风险识别与拒答效果的检验

现在固定预测器和分数，直接观察拒绝某些输入能否留下更低损失的预测。分数未校准也可能正确排序错误，常数概率虽校准却不能排序。**选择性预测**（selective prediction）允许拒答并只自动处理部分输入，我们要同时衡量接受风险与放弃的自动处理量。

记自动接受函数 $g(\boldsymbol{x}) \in \{0,1\}$、预测损失 $\ell(f(\boldsymbol{x}), y)$。接受比例用全体请求作分母，接受风险则只对被接受请求取平均：

$$
\begin{aligned}
c(g) &= \mathbb{P}(g(\boldsymbol{x}) = 1), \\
R_{\mathrm{sel}}(f, g) &= \frac{\mathbb{E}[\ell(f(\boldsymbol{x}), y) g(\boldsymbol{x})]}{c(g)}, \qquad c(g) > 0.
\end{aligned}
\tag{11.7}
$$

在独立测试中，令 $u(\boldsymbol{x})$ 越大表示越不确定，按 $g_t(\boldsymbol{x}) = \mathbb{I}\{u(\boldsymbol{x}) \le t\}$ 筛选。记录分数、预测与标签后，分别估计两项：

$$
\begin{aligned}
\hat{c}(t) &= \frac{1}{n} \sum_{i=1}^{n} g_t(\boldsymbol{x}_i), \\
\hat{R}_{\mathrm{sel}}(t) &= \frac{\sum_{i=1}^{n} \ell(f(\boldsymbol{x}_i), y_i) g_t(\boldsymbol{x}_i)}{\sum_{i=1}^{n} g_t(\boldsymbol{x}_i)}.
\end{aligned}
\tag{11.8}
$$

没有接受样本时第二项无定义。改变 $t$ 得到 $(\hat{c}(t), \hat{R}_{\text{sel}}(t))$ 风险—处理比例曲线；同一比例上更低风险，说明当前测试中的排序保留了较低损失输入。随机拒答可作参照，帮助区分风险识别与单纯减少工作量。

**示例 11.2　相同拒答比例下的不同效果**　构造十封测试邮件，其中两封分错，损失取零一值。甲把两封错误排为最不确定，拒绝后八封均正确，经验风险 0；乙拒绝的却是两封正确邮件，八封中仍错两封，风险 $2/8 = 25\%$，比全处理的 20% 高。随机拒绝两封，留下部分的期望错误率仍 20%。拒答量相同，收益因排序而异，这项比较没有检验分数的概率校准。

图 11.4把同十封邮件按两种分数排序。接受区域的编号给出式 (11.8)的分母，错误计数给出分子。两者都接受八封，风险不同，说明减少处理量只有在筛选出高损失输入时才降低当前接受风险。

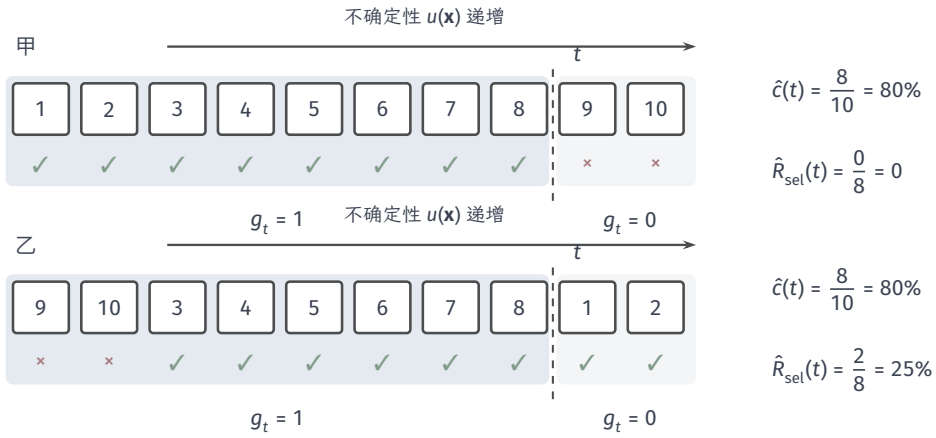


图 11.4　按示例 11.2将十封邮件依不确定性递增排列，9、10 号的 × 为错误，其余 ✓ 为正确。蓝区接受八封、灰区拒绝两封。$\hat{c}(t)$ 以全部为分母估计 $c(g_t)$，$\hat{R}_{\text{sel}}(t)$ 以接受数为分母估计 $R_{\text{sel}}(f, g_t)$；经验零风险仍未保证总体零风险。

比较曲线之后，还需独立验收部署工作点。验证集确定阈值，冻结后在测试集报告接受数、风险及区间；接受数过少时，零错误仍未支持很小的总体风险。直接选择测试曲线上最有利点会再次让测试参与选择。

图 11.5计算每次接受 1 至 10 封的风险。甲到第九封才接纳错误，乙第一封便接纳错误，全部处理时都回到 $2/10$。曲线随具体排序变化，不能先假定风险随阈值单调。

最大类别概率阈值是常见接受规则，却只在特定损失下对应风险。误拦比漏放昂贵时，类别和代价要一起进入规则；同一 0.9 概率支持自动隔离或仅提醒核查的条件可能不同。

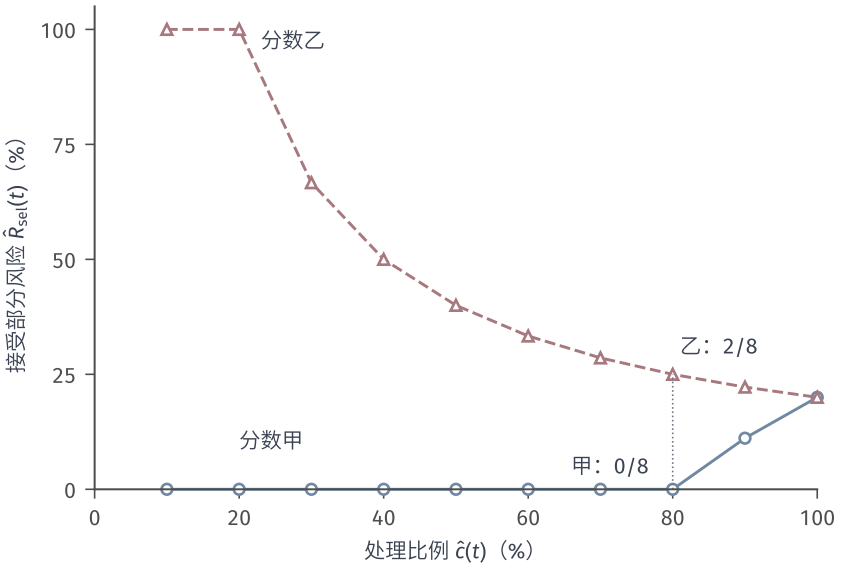


图 11.5 在图 11.4完整排序上依次接受 1 至 10 封，空心圆为甲、虚线三角为乙。80% 处理时风险 0 与 25%，全部处理都 20%。点为教学计数的精确比值，无测量误差；零接受时风险无定义，未画对应点。

为推导理想接受规则，设自动预测条件损失为 $r(\boldsymbol{x})$，无额外错误的人工复核固定成本 $c_{\mathrm{r}}$。像示例 10.2一样逐输入比较，$r(\boldsymbol{x}) \le c_{\mathrm{r}}$ 才自动处理。只有零一损失、真实类别概率已知且自动选择最大概率类别时，才有 $r(\boldsymbol{x}) = 1 - \max_k p(y = k \mid \boldsymbol{x})$，由此得到最大概率阈值。人工错误或拥堵存在时，复核成本还随输入、负载变化。

例如 100 个请求仅接受 10 个，错 1 个，接受风险 10%，全体“接受且错误”比例却只有 1%。降低处理量可以缩小后者，却不能由此判定前者满足既定的接受风险要求。完整处置还要纳入人工错误和延迟，两个分母都不能隐去。

### 11.2.3 局部条件下的检验

在声明总体中，一种语言的错误可能被其他语言的较好结果掩盖。我们保持使用范围不变，按重要子群体重算概率、覆盖与选择风险，确定总体证据对哪些人和条件成立。这是对前两类指标做条件化检验。

切片由使用要求预设，例如语言、设备、时间或任务。记组 $S$ 中的样本索引为 $I_S$、数目为 $n_S = |I_S| > 0$，集合覆盖只在这组取均值：

$$\widehat{\mathrm{Cov}}_S = \frac{1}{n_S} \sum_{i \in I_S} \mathbb{I}\{y_i \in C(\boldsymbol{x}_i)\}. \tag{11.9}$$

比较组内目标时，一起保存样本数、区间长度或集合大小及覆盖置信区间。组内校准重新比较概率和事件频率，组内拒答重新计算接受比例与风险；

风险分母是该组接受数。没有接受样本便没有自动处理风险的直接经验估计。

构造 1000 封邮件，其中常用语言 900 封、少见语言 100 封，分别覆盖 846 和 54 封。总体为 $900/1000 = 90\%$，组内却为 94% 和 54%。若承诺每种语言 90%，总体计数没有验证这条要求，各组还需估计误差。概率图和拒答曲线也可能被平均掩盖。

小切片的估计波动更大。区间包含不达标值时，证据尚不足以确认达标；点估计接近也不能确认组间相同。大量切片中的极值还可能来自偶然波动。看到错误再选择的切片用于诊断，确认结论需新资料或多重比较处理；有限组检验也没有覆盖每个输入。

切片检验只细分原来的总体。若时间、来源、设备或扰动已经进入新范围，就改变了评价数据与未来输入的关系，需要重新声明变化及任务语义。下一章研究这种扩展，并检查变化后预测、不确定性和拒答是否共同失效。

承诺涉及概率解释、风险排序和重要局部条件时，三类证据需共同支持；只承诺其中一项，就选择对应的事件、效率或损失检验。复合承诺的一项失败指出相应缺口，全部达标也只在声明数据和误差内得到支持，不能升级为任意未来输入保证。

## 11.3 可靠性的保证

前一节检验现有输出，现在要构造满足预设要求的程序。先确定保证的对象和条件，再分别处理预测范围覆盖及行动风险。覆盖分支既研究可交换样本的一次预测，也研究连续反馈中的长期频率；风险分支研究完整程序的行动损失。事件不同，两类保证不能替换。

### 11.3.1 保证对象与成立条件

保证需要把事件、目标、总体、时间和数据关系连同概率空间写清。随机性可来自校准与新样本、验证集或连续反馈。结果进入集合是覆盖事件，自动行动代价是风险对象；覆盖没有保证集合够小，任取其中一个答案也未必正确。接受风险降低还没有证明全部请求成本下降。

数据取得方式和流程支持独立同分布、可交换或可观察反馈等条件，低训练损失不能推出它们。共形用校准秩将交换性转为覆盖，集中界用经验损失控制总体风险，在线法用误差反馈控制长期频率，下面沿这些机制构造保证。

量词还区分保证强度。边际覆盖同时平均校准集和新样本，期望风险平均未来损失，高概率风险则要求，以至少 $1-\delta$ 的概率，随机验证集选出的程序满足总体风险限值，其中 $0 < \delta < 1$ 为预先设定的验证失败概率上

限。边际平均可能容许少数校准集产生较差程序，高概率结论另限制验证抽取后选中风险超限程序的概率，通常需要更多样本或更保守选择。报告时应写出每层随机对象。

### 11.3.2 预测范围的覆盖保证

**可交换数据下的边际覆盖** 若要求真实目标进入输出范围，我们可以按预测偏差确定可接受候选。**共形预测**（conformal prediction）用校准样本中的分数排序设阈值；已训练模型提供分数，覆盖有效性则由数据关系和秩保证，不要求模型概率本身校准[4]。

[4] A. N. Angelopoulos, S. Bates, *A Gentle Introduction to Conformal Prediction and Distribution-Free Uncertainty Quantification* In arXiv preprint arXiv:2107.07511, 2022

此处的共形校准选择集合阈值，区别于概率校准的频率匹配。不准确概率仍可能经共形得到有效但很大的集合；概率质量良好而校准与新样本关系错误，覆盖也可能失效。两种“校准”要按各自事件判断。

先固定训练得到的评分 $s(\boldsymbol{x}, y)$，大值表示候选与模型较不相符，训练与校准资料分开。假设给定训练资料及训练所用随机性后，$n$ 个校准样本与一个未来样本可交换，且同一固定评分用于它们。对校准样本计算 $s_i = s(\boldsymbol{x}_i, y_i)$，目标错误水平 $\alpha \in (0,1)$ 确定接受秩和集合：

$$k = \lceil (n+1)(1-\alpha) \rceil, \qquad C_\alpha(\boldsymbol{x}) = \{ y : s(\boldsymbol{x}, y) \le q \}, \tag{11.10}$$

$k \le n$ 时取第 $k$ 个顺序统计量为 $q$，$k = n+1$ 时取 $q = +\infty$。高覆盖要求若超过样本能提供的有限阈值，全集仍保持有效性，却可能失去区分信息。

在上述条件下，未来分数的可交换秩使这一构造满足

$$\mathbb{P}\big(y_{n+1} \in C_\alpha(\boldsymbol{x}_{n+1})\big) \ge 1 - \alpha.$$

给定训练资料及训练随机性后，这一概率仍同时平均校准和未来样本；解除训练条件后，不等式同样成立。使用 $\le q$ 纳入边界并列分数只增加覆盖（可参考第一卷“随机变量”章的“拆分共形的有限样本覆盖”定理）。覆盖目标固定以后，还需比较评分造成的范围大小与后续行动代价。

绝对残差 $s(\boldsymbol{x}, y) = |y - f(\boldsymbol{x})|$ 产生回归区间 $[f(\boldsymbol{x}) - q, f(\boldsymbol{x}) + q]$，分类可用 $s(\boldsymbol{x}, y) = 1 - p(y \mid \boldsymbol{x})$ 保留分数不超 $q$ 的类别。评分影响宽度而非上述边际逻辑。比较评分器应固定覆盖目标，在独立样本比较平均长度或大小，非对称成本任务还需另外比较损失。

边际定理没有对每个固定输入或每批固定校准数据承诺同样覆盖。组内保证需足够样本及数据关系，变化环境需新联系或在线目标。“分布无关”因此不能理解成完全无抽样条件。

图 11.6依次显示独立训练评分、校准排序与新输入范围。交换性承担覆盖论证，图中宽度只说明构造，不能直接读作覆盖证据。

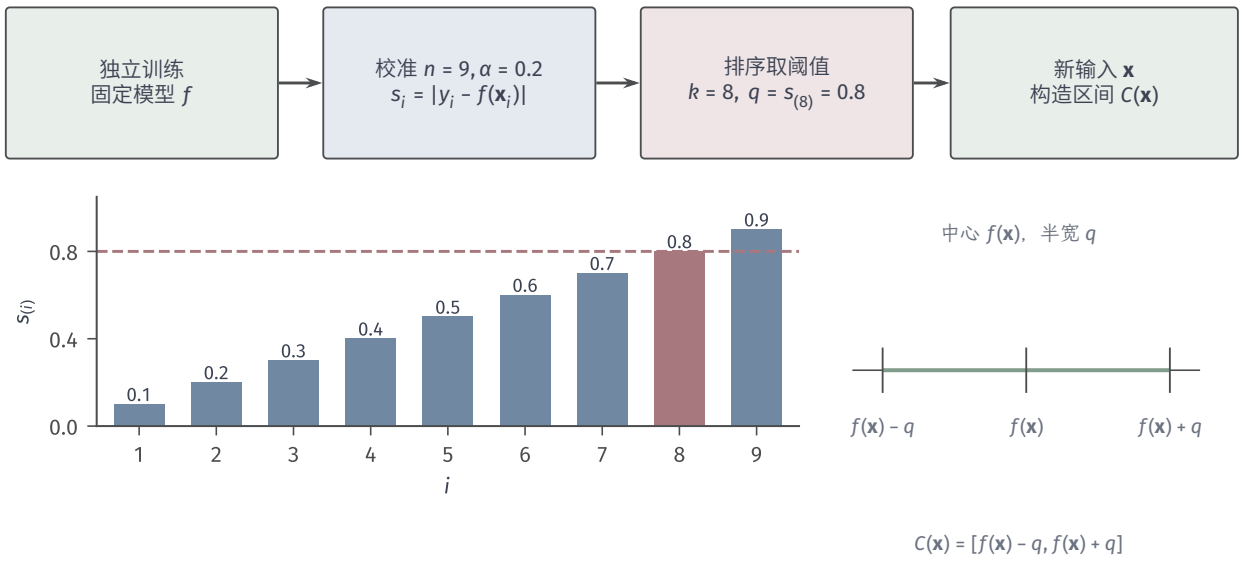


图 11.6 独立训练先确定评分，再由校准秩选择集合阈值。教学残差 $0.1, 0.2, \ldots, 0.9$ 取 $n = 9, \alpha = 0.2$，于是 $k = 8, q = 0.8$；绝对残差给右侧区间。图解释排序和构造，没有测量覆盖率。

**自适应范围与条件覆盖边界** 边际保证之后，我们还要分别问：区间能否适合输入难度，覆盖能否对局部人群成立。前者调整信息量，后者改变保证范围；宽度随输入变化并未自动回答局部覆盖。

固定宽区间可能在低噪声输入浪费宽度，在高噪声输入仍不够宽。Romano、Patterson 和 Candès 的**共形分位数回归**（conformalized quantile regression, CQR）先用学习的上下分位点适应输入，再以共形分数修正覆盖[5]。

[5] Y. Romano, E. Patterson, E. J. Candès, *Conformalized Quantile Regression* In arXiv preprint arXiv:1905.03222, 2019

设训练阶段用分位数损失分别拟合 $0 < \tau_{\mathrm{l}} < \tau_{\mathrm{u}} < 1$ 对应的 $\hat{q}_{\mathrm{l}}(\boldsymbol{x})$、$\hat{q}_{\mathrm{u}}(\boldsymbol{x})$，并保证上下顺序。目标错误 $\alpha$ 常取两端分位为 $\alpha/2$ 和 $1-\alpha/2$，拟合正确性影响效率而非共形有效性。为计算目标偏离原区间的程度，使用

$$s(\boldsymbol{x}, y) = \max\{\hat{q}_{\mathrm{l}}(\boldsymbol{x}) - y,\ y - \hat{q}_{\mathrm{u}}(\boldsymbol{x})\}. \tag{11.11}$$

在区间外，最大值是越界距离；内部则非正。用式 (11.10)取得阈值 $q$ 后，范围为

$$[\,\hat{q}_{\mathrm{l}}(\boldsymbol{x}) - q,\ \hat{q}_{\mathrm{u}}(\boldsymbol{x}) + q\,].$$

$q > 0$ 扩张，$q < 0$ 收缩，必要时可为空。交换排序仍给边际覆盖，短而有用则需要基础分位点反映局部噪声。

构造两个原区间 $[8, 12]$ 和 $[0, 20]$，统一修正 $q = 2$ 得到 $[6, 14]$ 和 $[-2, 22]$。修正相同而宽度仍不同，说明有效性不依赖拟合正确与效率依赖模型可以并存；这没有给两个固定输入各自提供条件覆盖。

分类也存在难度差异。Romano、Sesia 和 Candès 按类别概率累计质量构造自适应集合：概率集中时保留少数类别，分散时保留更多候选[6]。

一种评分先把类别按概率降序排列，再计算截至候选类别的累计概率，独立资料校准阈值；原方法还随机化边界类别。单类别固定阈值可能排除差别很大的总质量，累计评分处理这一问题。概率错误时有效性仍来自共形校准，自适应并不等于逐输入保证。

[6] Y. Romano, M. Sesia, E. Candès, *Classification with Valid and Adaptive Coverage* In Advances in Neural Information Processing Systems, 2020

把边际要求提升到每个输入会遇到信息限制。Barber 等说明，在足够一般的连续输入、实值输出问题中，面向所有分布的非平凡精确条件覆盖存在根本障碍[7]。

[7] R. F. Barber, E. J. Candès, A. Ramdas, R. J. Tibshirani, *The Limits of Distribution-Free Conditional Predictive Inference* In arXiv preprint arXiv:1903.04684, 2020

有限数据无法识别所有细小区域的结果分布：两个总体可以在已观察位置相同，在少样本区域的尾部不同。要同时保护所有候选总体，区间可能只能很宽。更大网络没有增加这里缺失的信息，需要平滑或分布假设，或者放宽保证对象。

可以预设有限组并分别校准，也可在受限切片族要求近似覆盖。细组增加针对性，却减少样本，使秩修正更粗且可能保守；集合大小仍受组内分数影响。预设组的交换性支持组内论证，事后任意挑组不能照搬。公平性章也将沿用这一区分，为受影响人群另建证据。

**变化环境中的长期覆盖** 若部署不断获得标签，我们可以使用已发生的未覆盖来调整下一轮范围，而不只固定阈值。Gibbs 和 Candès 的**自适应共形推断**（adaptive conformal inference, ACI）调整名义错误水平，所控制的对象由一次预测变为长期覆盖频率[8]。

[8] I. Gibbs, E. Candès, *Adaptive Conformal Inference Under Distribution Shift* In arXiv preprint arXiv:2106.00170, 2021

记目标错误比例 $\alpha$，内部名义水平 $a^{(t)}$。基础集合族 $C_t(\boldsymbol{x}; a)$ 满足 $a' < a$ 时 $C_t(\boldsymbol{x}; a') \supseteq C_t(\boldsymbol{x}; a)$，较低错误水平给较宽范围。第 $t$ 轮先预测，标签 $y_t$ 可见后计算 $e_t = \mathbb{I}\{y_t \notin C_t(\boldsymbol{x}_t; a^{(t)})\}$，再更新

$$a^{(t+1)} = a^{(t)} + \gamma(\alpha - e_t), \qquad \gamma > 0. \tag{11.12}$$

未覆盖使下一名义水平减小，倾向扩张范围；覆盖则逐渐提高名义错误水平。为了检查累计错误，我们将递推求和：

$$\frac{1}{T}\sum_{t=1}^{T} e_t - \alpha = \frac{a^{(1)} - a^{(T+1)}}{\gamma T}.$$

内部状态有界时，右侧趋零，长期错误平均趋于 $\alpha$。这是反馈更新的代数结论，不要求每轮独立同分布。

有界状态是关键条件。原法将分位函数扩到通常范围外，$a < 0$ 允许全集、$a > 1$ 允许空集，反馈才推回范围。若直接截断到 $[0, 1]$，不能继续套

用无截断恒等式。全集与空集也揭示代价：长期比例受控仍可能伴随无用的单轮输出。

学习率 $\gamma$ 在恢复速度和波动间取舍，大值响应快而范围波动大，小值平稳而突变恢复慢。标签延迟、反馈仅来自接受样本，或错误集中在某类输入，都需要重审可观察性和目标。长期平均没有保证短窗口，更没有保证高损失的单封邮件正确。

### 11.3.3 决策程序的风险保证

范围覆盖之后，行动仍需另行评价。共形风险控制将校准思想用于参数化损失族，但保证依赖有界性、风险单调结构、样本关系及选择规则[9]。此处保留这一方法入口；下面实际推导有限候选程序的高概率期望风险界，把验证前冻结与独立验证作为明确条件。

[9] A. Angelopoulos, S. Bates, A. Fisch, L. Lei, T. Schuster, *Conformal Risk Control* In International Conference on Learning Representations, 2024

**固定候选程序的高概率风险界** 先把预测器、接受阈值和拒答规则组合为程序，在验证前冻结 $K$ 个候选。程序 $j$ 的损失 $L_j \in [0,1]$，总体风险为 $R_j = \mathbb{E}[L_j]$。对 $n$ 个独立同分布验证样本，记损失 $L_{j,i}$ 及均值 $\hat{R}_j = n^{-1}\sum_{i=1}^{n} L_{j,i}$。为了在验证后选择仍保持风险保证，我们要让全部候选的上界同时成立。Hoeffding 界将单个失败概率设为 $\delta/K$，联合界便给出

$$\mathbb{P}\left(\forall j,\ R_j \le \hat{R}_j + \sqrt{\frac{\log(K/\delta)}{2n}}\right) \ge 1-\delta. \tag{11.13}$$

其中 $\delta \in (0,1)$，并事件概率至多 $K(\delta/K) = \delta$。可在上界达标者中选择验证经验处理比例最高者，同时界不因选择破坏。总体处理量却未获保证。记 $A_j$ 为程序 $j$ 自动接受请求的指示，服务承诺还需 $\mathbb{E}[A_j]$ 的下置信界，并联合筛选。没有候选达标时只能报告证据不足或改变策略，经验风险最低不能替代达标。

同时界只覆盖预先冻结候选，不能任意用同一验证资料生成新程序。零一损失若将拒答计零，约束的是全体中“接受且错误”的概率，并非式 (11.7)的条件风险。也可把拒答成本纳入归一化到 $[0,1]$ 的 $L_j$，直接评价完整程序。

**自动处理部分的条件风险界** 若承诺以自动接受部分为分母，我们需对分子和分母同时建立证据。记冻结程序 $j$ 的接受指示 $A_j(\boldsymbol{x}) \in \{0,1\}$、损失 $\ell_j \in [0,1]$，验证联合损失均值 $\hat{J}_j = n^{-1}\sum_i A_j(\boldsymbol{x}_i)\ell_j(\boldsymbol{x}_i, y_i)$ 和比例

$\hat{c}_j = n^{-1}\sum_i A_j(\boldsymbol{x}_i)$。以 $b_n = \sqrt{\log(2K/\delta)/(2n)}$ 同时控制 $K$ 个分子上界与 $K$ 个分母下界，则至少 $1-\delta$ 的概率下，对所有 $\hat{c}_j > b_n$ 有

$$R_{\mathrm{sel},j} = \frac{\mathbb{E}[A_j \ell_j]}{\mathbb{E}[A_j]} \le \min\left\{1, \frac{\hat{f}_j + b_n}{\hat{c}_j - b_n}\right\}. \tag{11.14}$$

分母下界越接近零，上界越弱；$\hat{c}_j \le b_n$ 时这套构造无法给有用证据，并非证明模型必然不可靠。需要更多独立验证样本、不同接受规则或更适合损失的界来缩小缺口。

**候选程序的构造与独立验证** 筛选界不保证候选中有达标者，候选质量仍要通过独立训练提高。可以固定预测器并改变阈值，也可以联合学预测和选择。Geifman 和 El-Yaniv 的 SelectiveNet 直接训练接受区域的表现，为仅按现有置信截断提供另一种构造路线[10]。

[10] Y. Geifman, R. El-Yaniv, *SelectiveNet: A Deep Neural Network with an Integrated Reject Option* In Proceedings of the 36th International Conference on Machine Learning, 2019, pp. 2151–2159

为同时学习接受风险与处理量，记软接受权重 $g_i \in [0,1]$、损失 $\ell_i$、目标比例 $c_0$，分母为正，考虑目标

$$\frac{\sum_i g_i \ell_i}{\sum_i g_i} + \lambda\left(\max\left\{0, c_0 - \frac{1}{n}\sum_i g_i\right\}\right)^2, \tag{11.15}$$

$\lambda > 0$ 控制比例不足的惩罚。第一项降低保留区域损失，第二项阻止通过只保留少量样本获低风险。SelectiveNet 还用辅助预测头在全体样本训练，避免特征尚未学好便忽略大部分输入，并将其损失与选择损失加权。训练目标没有提供测试风险保证，实际阈值和风险仍需独立选择、验证。

训练构造候选并尝试改善风险—处理量取舍，独立验证给出同时上界，选择在有效上界中决定可用程序。改善幅度由独立比较确认。验证后若继续依据结果训练候选，就改变了独立关系，需新数据或能处理适应性的保证。

### 11.3.4 两类保证的比较与适用边界

覆盖的输出对象是 $C(\boldsymbol{x})$，失败事件是目标未进入集合；大小或长度另表示信息效率。风险对象是预测、接受和行动的完整程序，损失可包括误判、拒答或其他后果，未必输出集合。选择保证之前应先确定要约束哪一个对象。

对象确定后，还要确定概率与数据条件。拆分共形在交换样本下给边际覆盖，ACI 在可见反馈与有界状态下给长期频率，有限程序界在独立同分布验证下对验证抽取给高概率风险。三者分别评价一次预测、长序列和程序验收，不能只按数值大小排强弱。

集合可以进入决策，但由覆盖推行动风险还需规定用法，并给未覆盖、集合过大与拒答定义损失。低风险程序也不自动给校准概率或覆盖集合。需要容纳真实结果时，声明覆盖与效率；需要限制后果时，声明行动损失与处理量；两者都需时分别证明和检验。

部署时冻结主张、程序、阈值与事件，保存数据关系、反馈可见性和复验时间窗。无标签代理变化用于触发调查，不能单独证明真实失效；关键数据关系失去依据，或带标签监测按预设规则越过覆盖、风险阈值时，应限制处理、转人工或暂停。恢复前在重新声明的总体和时间内，独立复验事件、目标、置信及适用的处理量。程序或阈值变化形成新主张。ACI 只控制可见反馈下长期覆盖，下一章还需补充漂移诊断、无标签预警和一般处置。

## 11.4 本章小结

邮件概率 0.9 需要指明事件，并以数据检验对应频率；生成词元概率同样不能直接表示事实正确。不确定性、分类准确与校准分别描述不同对象，输出用于排序或行动时还需评价相应信息和损失。

后验近似和集成表达候选规律的分歧，条件分布与分位点表达固定观测下的结果波动。两者组成预测分布和范围，仍只是待检验表达。共同盲点、模型假设与估计误差都可能使表达失真。

校准、评分和覆盖检查数值，风险—处理比例曲线检查筛选，局部复测检查重要群体。复合使用承诺需合用这些证据，单项要求则采用对应的检验。总体指标不足以代替条件化或行动判断。

覆盖与决策风险的保证还各有量词和数据条件。共形边际有效性不等于逐输入覆盖，在线长期频率允许短期失败，选择训练也仍需独立验证。生成任务还要区分措辞、语义与事实。条件改变时先限制，再按重新声明的事件和关系复验；代理预警或长期平均不能单独支持恢复。下一章研究输入和环境改变怎样破坏预测及这些承诺。

**延伸阅读** Guo 等的校准研究比较分类与概率质量，Angelopoulos 与 Bates 的综述则说明基础预测器、校准数据和效率在有限样本覆盖中的不同作用，可与本章的检验及构造对照阅读[11,12]。

生成任务可继续阅读语义熵与共形风险控制：前者区分措辞和语义变化，后者需要先定义开放输出的风险事件，二者都不能把低不确定性当作事实正确[13,14]。

[11] C. Guo, G. Pleiss, Y. Sun, K. Q. Weinberger, *On Calibration of Modern Neural Networks* In Proceedings of the 34th International Conference on Machine Learning, 2017, pp. 1321–1330

[12] A. N. Angelopoulos, S. Bates, *A Gentle Introduction to Conformal Prediction and Distribution-Free Uncertainty Quantification* In arXiv preprint arXiv:2107.07511, 2022

[13] L. Kuhn, Y. Gal, S. Farquhar, *Semantic Uncertainty: Linguistic Invariances for Uncertainty Estimation in Natural Language Generation* In International Conference on Learning Representations, 2023

[14] G. Loaiza-Ganem, K. Zhang, W. Cui, M. T. Law, K. K. Leung, *Conf-Gen: Conformal Uncertainty Quantification for Generative Models* In Proceedings of the 43rd International Conference on Machine Learning, 2026, pp. 80383–80412

第 12 章

# 鲁棒性

一个邮件分类器通过旧月份测试，到了新月份却频繁误拦。图片压缩可能改变输入测量，正常邮件采用原垃圾模板则可能改变特征与标签的联系。这两种情况需要不同证据和补救。我们先确定部署要承受什么变化，再问模型在这些变化中能否继续完成任务。

**鲁棒性**（robustness）就是模型在规定变化范围内维持任务表现的能力，判断时要写出变化对象、范围和指标。若模型失效或证据不足，系统还需识别、拒绝高风险输入与回退，这里称为**变化应对能力**（resilience to change）。模型表现和系统止损分别评价：变化风险、局部认证和范围外识别提供不同证据；训练约束、新环境信息与受限自动处理则对应不同改进。第 9章给出变化下的可学习性条件，本章将它们接到检验和改进。

第 10章的要求层在这里规定允许改变哪些条件，以及变化后任务风险或表现至少满足什么标准。没有这项声明，“稳健”还没有确定的评价对象。

上一章的可靠性主张依赖数据与未来输入的关系。关系改变后，风险测试、局部认证和拒绝检验分别检查哪些证据仍有效；模型或来源继续改变，则需监测、触发、回退和复验。要求、证据和生命周期条件由此共同限定鲁棒性。

允许变化也可由对手寻找。本章按允许集合与损失讨论局部方法，第 17章再加入攻击权限、资源和损害路径。测量误差与主动扰动可共享局部稳定性工具，完整安全范围却还包括其他环节。

## 12.1 模型的鲁棒性

图像压缩可以改变邮件输入，但模型若仍正确，就没有在这项变化中失效；模板更换也可能只让特定模型失败。我们因此分别研究变化范围与失效机制：范围决定测试什么，机制解释何以出错。同一种变化可能触发不同机制，同一种捷径也可被多种变化暴露。

### 12.1.1 变化范围与性能要求

先固定参考邮件总体 $\mathcal{P}$ 与预测器 $f$，考察每封邮件可发生的标签保持变化。任务给出非空允许集合 $U(\boldsymbol{x})$，含原输入 $\boldsymbol{x}$，其中每个 $\boldsymbol{x}'$ 的正确标签仍为 $y$。以较大值表示较差预测的损失 $\ell$，若要求覆盖每个允许变化，就先对集合内损失取上确界，再对参考样本平均：

$$R_{\mathrm{pert}}(f)=\mathbb{E}_{(\boldsymbol{x},y)\sim\mathcal{P}}\left[\sup_{\boldsymbol{x}'\in U(\boldsymbol{x})}\ell(f(\boldsymbol{x}'),y)\right]. \tag{12.1}$$

随机抽扰动只给平均，可能漏掉少量高损失点，上确界对应全称范围要求。预设容限 $\rho_{\mathrm{pert}}$ 时，可要求 $R_{\mathrm{pert}}(f)\le\rho_{\mathrm{pert}}$。像素、等义文本或测量误差怎样进入 $U$，都由任务决定；删除否定词虽少改字符却改变标签，不能要求继续保留原输出。

式 (12.1)保留外层 $\mathcal{P}$，只改变单样本邻域。新月份的群体比例或标签关系却可能改变整个联合分布，因此需要环境集合 $\mathcal{E}$ 及每个环境的 $\mathcal{P}_e$。令参考 $0\in\mathcal{E}$ 且 $\mathcal{P}_0=\mathcal{P}$，沿用损失计算 $R_e(f)=\mathbb{E}_{(\boldsymbol{x},y)\sim\mathcal{P}_e}\ell(f(\boldsymbol{x}),y)$，以比较环境风险。集合应声明群体、标签比例、输入边缘或条件规律的允许变化，见第 9.1.2节。可分别约束 $\sup_{e\in\mathcal{E}}R_e(f)\le\rho$ 和 $\sup_{e\in\mathcal{E}}[R_e(f)-R_0(f)]\le\delta$，局部证书通常不推出它们。前者约束风险水平，后者约束增加量；一直很差的模型也可能增加很小，所以两项应共同报告。

> **示例 12.1　总体表现掩盖群体脆弱性**　构造旧环境，其中 99% 邮件使用常见模板，错误率 1%，少见模板占 1%，错误率 50%。按组比例加权，总错误率为 $0.99\times0.01+0.01\times0.5=1.49\%$。新环境只把少见模板比例提高到 30%，组内错误不变，平均错误便达到 15.7%。这里参数和组内标签规律都未改变，比例变化已能造成总体退化。

图 12.1将搜索和认证分开。允许集合中的一个错误足以反驳单样本的全称正确主张，但总体容限还需按抽样单位聚合；证明整个邻域稳定，则要有覆盖邻域的认证依据。后面分别检验这些对象。

### 12.1.2 失效机制与信息缺口

允许范围确定了测试对象，失败原因还要另查。附近决策边界可导致局部翻转，高错误组增加占比可抬高平均风险，特征与标签联系改变可使旧规则失效。模板比例例子属于第二项，增加的是困难样本权重，并未制造新的组内错误。与标注错误、测量异常等数据问题区分，才能确定补救需要什么信息。

仅以当前样本的分类损失为目标时，训练奖励这些条件下的预测质量，不会自行判别所用关系是否可迁移。若垃圾邮件常带某页脚，模型可借页

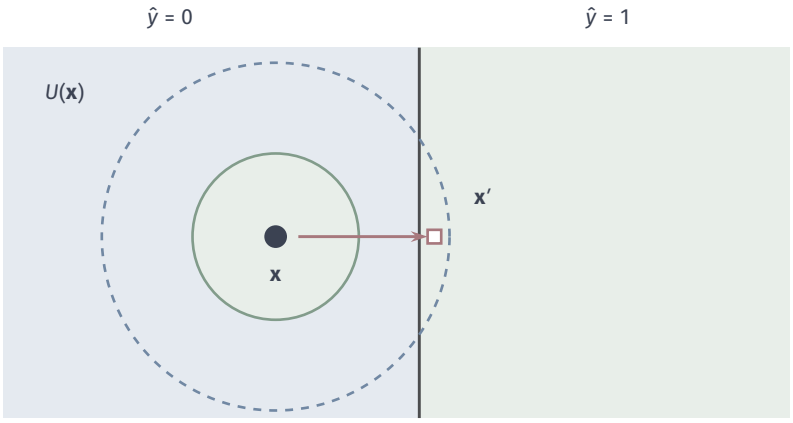


图 12.1 虚线圈为允许集合 $U(\boldsymbol{x})$，内圈为已认证稳定范围，方点 $\boldsymbol{x}'$ 在允许集合中跨越决策边界。尺寸仅示意集合关系，未取自随机平滑实验。搜索无反例尚未认证全允许范围。

脚答对；正常邮件后来也用它，旧依据便失效。**捷径学习**（shortcut learning）描述在训练条件有效、却无法支持预期迁移的规则。Geirhos 等据此分析背景、纹理依赖，并要求结合数据和评价条件判断[1]。

页脚是否捷径，取决于要求是否允许页脚改变而类别保持。在固定业务中，它也可能是合法依据。易读特征未必稳定，高维特征未必捷径，人工规则也会依赖过时相关；需要实际改变关系并观察预测，外观不能替代检验。

我们可以构造内容与模板不一致的对照。设垃圾邮件 90% 用模板甲，正常邮件 90% 用乙，只读模板已有 90% 准确率，原比例随机留出仍支持它。将模板均衡分给两类，模板规则便降到 50%。这是诊断所需的人为对照，没有说明所有模型都会学模板，却显示随机留出未检验模板改变后的不变性。

若现有的有限环境未提供排除捷径的信息，增加多样性才可能暴露它，但多样性须对应目标变化，近重复记录未必增加覆盖。若现有资料完全无法区分目标域的标签规律，复杂模型、正则或无标签适应也不能补造信息；定理 9.3给出了这类不可识别边界。

若真实标签关系改变，保持原答案反而违背任务。例如合法发件主体被接管，系统应利用新证据改变判断。我们要维持的是任务表现，只有标签保持时才可进一步要求输出不变；标签变化需要发现和学习新规律。

[1] R. Geirhos, J.-H. Jacobsen, C. Michaelis, R. Zemel, W. Brendel, M. Bethge, F. A. Wichmann, *Shortcut Learning in Deep Neural Networks* In Nature Machine Intelligence, 2020

## 12.2 鲁棒性的检验

检验现在分别回答三个问题：变化后任务风险是多少，指定邻域是否排除了预测翻转，范围未覆盖时能否识别并止损。带标签测试和认证评价模型，

监测、拒绝与回退评价系统应对。报警和稳定性没有互相蕴含关系，这三类证据要共同但分别解释。

### 12.2.1 变化条件下的风险检验

从要求出发选择测试：测量扰动尽量保留任务语义并改变噪声、分辨率或缺失率，跨环境使用新时间、来源或设备，切片检查聚合遗漏。每项都需记录强度、标签复核和所覆盖范围。

同一原样本的配对变体减少组成差异，便于隔离因素，真实新环境则保留因素耦合，二者不能替换。若增强策略已根据测试选择，还要另留环境或扰动组合，区分针对测试的适应与可迁移改进。

ImageNet-C 预设噪声、模糊、天气和数字处理等损坏及强度，ImageNet-P 考察连续小变化中的预测不稳定。它们使规定压力下的结果可重复比较，证据范围仍限于这些损坏和扰动，不能扩为所有自然或最坏变化[2]。

基准归一化分数也有特定基准。例如用参考分类器在某损坏上的累计错误作分母，再平均类型，得到相对表现而非部署错误。真实服务若主要遇到压缩，天气、噪声等权平均便未必对应收益。按类型和强度分解，连同原输入结果报告，才能解释归一化数值。

WILDS 将跨医院、相机位置、时间和地理区域的来源差异纳入任务，并规定划分与指标。它展示随机域内留出与按来源域外留出所回答的问题不同[3]。

变化还可能先使概率报告失准，随后才明显降低准确率。Ovadia 等在构造分布变化中同时比较不确定性方法的准确率、概率评分和校准，区分错误增加与对错误过于自信。结论仍应连同变化类型和强度使用[4]。

邮件时间划分要防止近重复和同一会话跨越训练与测试。目标是新机构时按机构留出，目标是未来月份时保留时间顺序，使未知因素对应划分单位。还需说明调参能访问哪些环境；利用目标标签选择与完全未见目标，不是同一设定。

平均风险之外，预先根据人群、来源或成本确定的关键组也需风险、样本数和区间。小样本低点估计不足以确认可靠。示例 12.1还说明，要分别报告组内错误与组比例，才能确定平均退化来自哪里。

在环境 $e$ 中，从 $\mathcal{P}_e$ 独立抽取 $n_e$ 个未参与拟合选择的带标签样本，分别估计风险及相对参考 0 的变化：

$$\begin{aligned} \widehat{R}_e(f) &= \frac{1}{n_e}\sum_{i=1}^{n_e} \ell(f(\boldsymbol{x}_{e,i}), y_{e,i}), \\ \widehat{\Delta}_e &= \widehat{R}_e(f) - \widehat{R}_0(f), \end{aligned} \tag{12.2}$$

[2] D. Hendrycks, T. Dietterich, *Benchmarking Neural Network Robustness to Common Corruptions and Perturbations* In International Conference on Learning Representations, 2019

[3] P. W. Koh, S. Sagawa, H. Marklund, S. M. Xie, M. Zhang, A. Balsubramani, W. Hu, M. Yasunaga, R. L. Phillips, I. Gao, T. Lee, E. David, I. Stavness, W. Guo, B. Earnshaw, I. Haque, S. M. Beery, J. Leskovec, A. Kundaje, E. Pierson, S. Levine, C. Finn, P. Liang, *WILDS: A Benchmark of in-the-Wild Distribution Shifts* In Proceedings of the 38th International Conference on Machine Learning, 2021, pp. 5637–5664

[4] Y. Ovadia, E. Fertig, J. Ren, Z. Nado, D. Sculley, S. Nowozin, J. V. Dillon, B. Lakshminarayanan, J. Snoek, *Can You Trust Your Model's Uncertainty? Evaluating Predictive Uncertainty Under Dataset Shift* In Advances in Neural Information Processing Systems, 2019

$\widehat{R}_e$ 说明风险水平，$\widehat{\Delta}_e$ 说明变化增加，两者按强度和预设组展开，区分原本较差与变化退化。容限 $\rho$ 需对照风险置信上界，点估计达标不充分。会话、机构、时间聚类要匹配估计和区间，纳入概率不同需加权；同原样本多变体或前后配对要保留依赖，不能当独立观测。多个环境、强度或组的同时承诺还需联合控制，逐项区间只支持逐项解释。

改进比较应同时包括新环境、原环境和关键群体。新模板收益可能伴随旧模板遗忘，针对已识别变化的更新也可能伤害其他输入。预设数据和停止规则，避免持续查看后仅报告最好时刻。

证据不足时，可保留模型、收窄自动范围或回退，限制不确定更新的损害。这些措施改变使用风险，未必改变被拒输入的分类表现，因此要与模型鲁棒性分开报告。

运行评价可冻结原模型，在同一时间窗口对照适应模型，标签返回后核算风险。在线选择更新时机需要处理重复检验；标签仅来自人工转交时，还需处理选择性观测，该子集错误率不代表全量。变化目标、独立检验与有效保证条件在这里继续共同发挥作用。

### 12.2.2 邻域内稳定性的认证

随机测试只覆盖已生成变体。若要求半径内每一点都不翻转，检验对象已成为全称命题，增加有限随机用例仍未证明它。

有限搜索对式 (12.1)只能提供损失下界。找到允许集合中的错误，可反驳该样本在全邻域正确的主张；搜索无果仍未排除这样的错误，总体容限还需按参考样本聚合判断。认证则需要函数变化的上界。设二分类分数在 $U(\boldsymbol{x})$ 中满足 $|f(\boldsymbol{x}')-f(\boldsymbol{x})| \le L\|\boldsymbol{x}'-\boldsymbol{x}\|_2$，半径 $r$ 球包含于 $U$，且 $f(\boldsymbol{x}) > Lr$，则任一点分数至少 $f(\boldsymbol{x})-Lr>0$。证书保持这个范数球中的符号，原标签若错，符号稳定也仍错。

图 12.2用二维平面显示变化上界保护的球。球外有同符号点，也有反例；没有证书只表示这份证明未判定它，不能当作失败。

我们也可先构造一个便于认证的新规则。**随机平滑**（randomized smoothing）给基础分类器 $h$ 的输入加噪，再以投票概率最大的类别形成 $g$，并列时按预先固定的规则裁决：

$$g(\boldsymbol{x}) = \arg\max_k \mathbb{P}_{\boldsymbol{\varepsilon}\sim\mathcal{N}(\mathbf{0},\sigma^2\boldsymbol{I})}\{h(\boldsymbol{x}+\boldsymbol{\varepsilon})=k\}. \tag{12.3}$$

这里 $\boldsymbol{x}\in\mathbb{R}^d$，$\boldsymbol{I}$ 为 $d$ 阶单位阵，$\sigma>0$ 为噪声标准差。高斯平移限制分类区域概率的变化，Cohen 等据此建立平滑分类器的 $\ell_2$ 证书[5]。认证对象因此是新规则 $g$。

[5] J. Cohen, E. Rosenfeld, Z. Kolter, *Certified Adversarial Robustness via Randomized Smoothing* In Proceedings of the 36th International Conference on Machine Learning, 2019, pp. 1310–1320

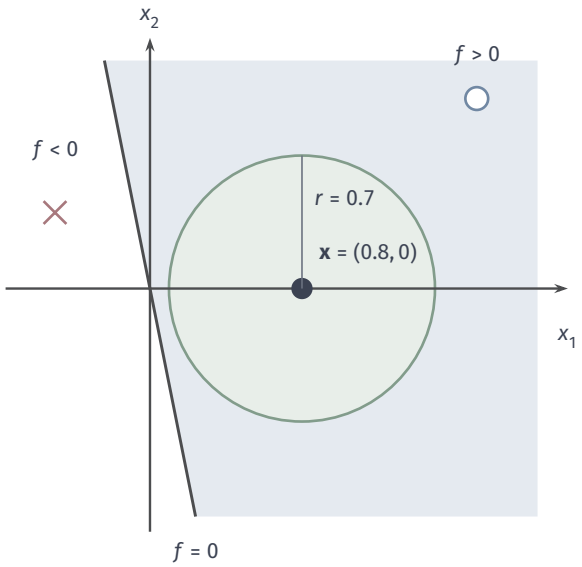


图 12.2 教学分数 $f(\boldsymbol{x}) = x_1 + 0.2x_2$ 在 $(0.8, 0)$ 取 0.8，$L = \sqrt{1.04}$，$r = 0.7$ 满足 $0.8 > Lr$，故闭球内符号正。深线为零边界，球外空心点正、叉点负；球外不受这份证书判定。证书保证符号保持，未判原标签正确。

记 $\underline{p}_a \in [0,1]$ 为类别 $a$ 的投票概率下界，$\overline{p}_b \in [0,1]$ 为所有其他类别投票概率的共同上界。若 $\underline{p}_a > \overline{p}_b$，高斯分布关系给出可保持胜出的扰动范围：

$$\|\boldsymbol{\delta}\|_2 < r_{\text{cert}}, \qquad r_{\text{cert}} = \frac{\sigma}{2}\left[\Phi^{-1}(\underline{p}_a) - \Phi^{-1}(\overline{p}_b)\right] \tag{12.4}$$

$\Phi$ 是标准正态分布函数，$\Phi^{-1}$ 为其分位函数，端点 0 和 1 按极限解释。范围内满足 $g(\boldsymbol{x}+\boldsymbol{\delta}) = a$。这是投票规则的保证，不保证一次带噪 $h$ 输出，也没有给原模型直接发证。

投票概率未知，需要蒙特卡洛抽样及有效置信界。二分类若已有 $\underline{p}_a = 0.9$，可取 $\overline{p}_b = 0.1$；$\sigma = 0.25$ 时半径约 $0.25 \times 1.282 = 0.3205$。这些是假定界，90% 经验票数不能直接替代。选择类别与估概率要独立采样，或用对选择有效的同时程序；界无法分开类别就拒绝认证。

更强噪声可能让类别票数接近或降低正确率，故增加 $\sigma$ 未必扩大实际半径。平滑还增加前向计算，报告应同时包括认证准确率随半径的曲线、成本与失败概率。认证准确率计数的是预测正确且证书覆盖半径的样本。单点采样界未同时保护整批或整条曲线，联合结论需分配失败概率或联合控制；它的随机性是估票抽样，与上一章校准和新样本覆盖不同。

给定目标开球半径 $r$，逐样本检查正确性和认证半径至少 $r$，再求两项同时成立的比例。同一规则也可报告搜索鲁棒准确率：搜索反例与成功证书分别判错、判定范围，二者均无结果时保留未判定。单点证书不保证测试代表未来，总体风险仍需抽样条件。

### 12.2.3 变化识别与拒绝效果的检验

输入离开已检验范围时，报警和人工转交可限制使用。我们分别检验识别条件的能力和识别带来的实际损失变化；这两项支持系统应对，却未证明分类器仍然正确。

**分布外检测**（out-of-distribution detection）以预设域内分布、输入单位和备择来源为参照，判断输入是否离开范围。未知语义类别、协变量变化与域内低密度困难样本是不同对象，实验域外标签只代表选定来源。距离、密度相关或输出分数可用于检测与阈值选择，低密度却未必难预测，高置信也未必熟悉。应按漏检、误报成本评价；有限参考资料无法统一识别任意未知分布。

固定异常分数后，分别保留正常资料与预定未知类别或来源，独立验证选阈值，测试误拒正常与误接纳未知的比例。排序曲线可比较分数，工作点需两种错误及成本。曲线下面积未直接计成本；FPR95 若把域内定义为正类，表示保留 95% 域内时误接纳域外的比例，必须核对分母和方向。

熟悉输入也可能错，陌生输入也可能正确。要评价止损，我们另取任务标签，计算接受风险、总体处理比例与转交成本，在相同处理量或成本下比较。第 11章的选择检验据此连接检测：域外标签检查陌生识别，任务标签检查错误降低。第 12.3.3节再构造检测分数。

**漂移检测**（drift detection）观察一段数据流的统计关系是否改变。输入改变未必抬高风险，输入边缘稳定也可能掩盖标签关系改变。缺标签时漂移只是调查或收窄使用的触发，不能决定新模型方向。

模板占比改变可被特征检验发现，模型若不依赖模板，风险却未必增加；发件主体被接管时，边缘输入近似不变，标签风险却可能改变。持续获得少量真实标签，才能把输入信号与错误、行动损失对照。第 11章的统计区间仍需匹配抽样，任意反复查看筛选的监测资料不能直接套用。

评价报警可保留时间顺序，将已知无变化与有变化段分别测试误报、漏报和延迟，并保存窗口、阈值、重置规则。真实起点未知时，只报告已核实统计差异及后续风险，不能把报警全部当真阳性。延迟标签回来后对照风险，报警触发拒绝或更新的收益代价再另行核算。

## 12.3 鲁棒性的增强

诊断决定干预对象。标签保持的局部错误需要约束输入行为，困难群体或环境捷径需要调整训练风险与依据，范围外输入需要拒绝，新环境信息则可能支持适应。这些措施可组合；前三类不要求持续改部署参数，适应还要处理状态更新、错误累积和遗忘。

干预前先排查数据污染。Huber 损失在小残差用平方、大残差用线性，稳健损失或重加权可减少极端样本的拟合影响。不过合法少数群体也可能残差大，机械降权会遗漏它们。异常或标签噪声与未学会的合法样本，需要数据诊断来区分。

### 12.3.1 输入变化下的行为约束

任务预期的标签保持变换 $T$ 可进入训练，以 $\ell(f(T(\boldsymbol{x})), y)$ 约束模型。无标签时可以比较变换前后的概率、分数或表示，但须指定差异量与权重。变换要保留任务含义，过强一致性会消去有意义差别。

也可约束不同样本之间的函数变化。**混合增强**（mixup）用同一权重对输入和标签分别插值，独热标签 $\boldsymbol{e}_y$ 给出

$$\begin{aligned} \tilde{\boldsymbol{x}} &= \lambda \boldsymbol{x}_i + (1-\lambda)\boldsymbol{x}_j, \\ \tilde{\boldsymbol{y}} &= \lambda \boldsymbol{e}_{y_i} + (1-\lambda)\boldsymbol{e}_{y_j}, \end{aligned} \tag{12.5}$$

$\lambda \in [0,1]$ 为共享的插值权重，通常由对称 Beta 分布抽取。软标签交叉熵按 $\lambda$ 和 $1-\lambda$ 分配两类损失，不强行让插值点继承某一个端点[6]。

两个端点类别不同时，$\lambda = 0.7$ 得到的软标签对这两类赋予 $(0.7, 0.3)$；混合输入的预测概率也取这个向量时，才与软标签吻合。插值增加形状约束，却需语义假设：按字节混合两封离散邮件通常无意义，表示插值也需核验。端点标签正确没有证明中间软标签是真实分布，所以它区别于式 (12.1)的标签保持邻域。

AugMix 则从同一图像生成多条随机增强链，混合视图并保留原图通路，还可训练预测一致性。它约束同一对象的合理变化组合，不规定跨类别的线性过渡[7]。

mixup 比较样本之间，AugMix 比较同一样本的视图。检查时要保留这两种假设，不能只说增加数据。增强前核对小目标、颜色或文字方向是否被破坏，增强后用未参与的损坏及组合复查迁移。

随机增强可能漏掉允许邻域中高损失位置。最不利训练关注这些位置，却也可能移动原数据边界。TRADES 将分类错误与边界不稳定相连，构造兼顾原分类和局部稳定的代理目标[8]。

令 $\boldsymbol{p}_\theta(\boldsymbol{x})$ 为多类别分布，候选参数为 $\Theta$、训练联合分布为 $\mathcal{P}_{\text{train}}$。原输入用负对数损失，邻域用分布偏离的上确界，形成

$$\begin{aligned} \min_{\theta \in \Theta} \mathbb{E}_{(\boldsymbol{x},y)\sim \mathcal{P}_{\text{train}}} \Big[ & -\log p_{\theta,y}(\boldsymbol{x}) \\ & + \beta \sup_{\boldsymbol{x}' \in U(\boldsymbol{x})} D_{\text{KL}}\big(\boldsymbol{p}_\theta(\boldsymbol{x}) \,\big\|\, \boldsymbol{p}_\theta(\boldsymbol{x}')\big) \Big], \end{aligned} \tag{12.6}$$

[6] H. Zhang, M. Cisse, Y. N. Dauphin, D. Lopez-Paz, *mixup: Beyond Empirical Risk Minimization* In International Conference on Learning Representations, 2018

[7] D. Hendrycks, N. Mu, E. D. Cubuk, B. Zoph, J. Gilmer, B. Lakshminarayanan, *AugMix: A Simple Data Processing Method to Improve Robustness and Uncertainty* In International Conference on Learning Representations, 2020

[8] H. Zhang, Y. Yu, J. Jiao, E. P. Xing, L. El Ghaoui, M. I. Jordan, *Theoretically Principled Trade-off between Robustness and Accuracy* In Proceedings of the 36th International Conference on Machine Learning, 2019, pp. 7472–7482

实际外层用样本平均，$\beta > 0$ 控制稳定性权重，$D_{\mathrm{KL}}$ 计量类别分布差异。第一项要求真实类别，第二项惩罚允许邻域中的最大预测偏离；有限内层搜索只近似下界。解释为鲁棒零一风险上界还需 TRADES 的分类校准和替代损失条件。去掉分类项，常数输出虽稳定却不能区分不同类别。

邻域本身也要核验。异类样本邻域重叠时，两边各自标签保持的要求冲突，不能靠加大权重解决。范围相容后再选择 $\beta$，内层近似仍增加计算，训练目标达标不等于形式证书。第 17章将研究搜索与梯度遮蔽检验。

图 12.3拆开式 (12.6)中的搜索和更新：固定参数找允许分布偏离，随后以分类和偏离损失调整参数。搜索只产生候选，尚未证明是全局最坏点。

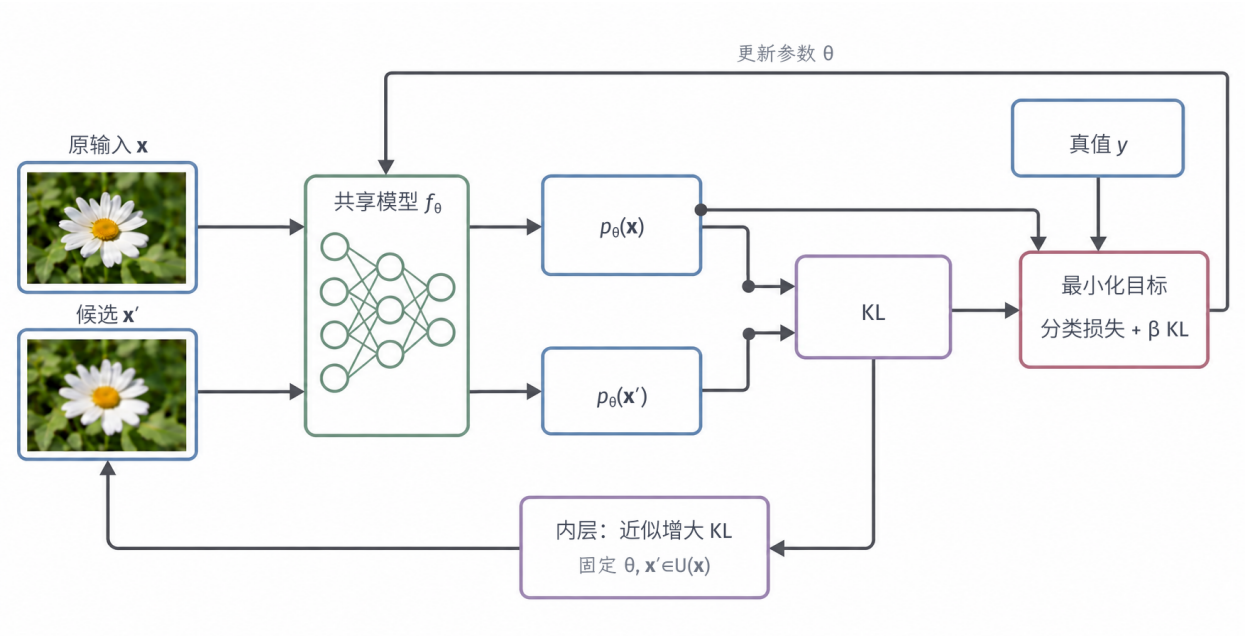


图 12.3　TRADES 内层固定参数，在 $U(\boldsymbol{x})$ 近似增大原、扰动预测之间的 KL；外层最小化原输入的分类损失与加权 KL，再重新搜索。共享模型分别处理两输入，原预测还独立进入分类损失。花朵样本和箭头均为示意，未提供实际扰动大小或全邻域形式证书。

图 12.4保持样本和扰动，比较有限教学候选。A、B、C 呈现取舍，D 却同时改善 B，所以连线不能认作所有任务共同的最优边界。

改变训练约束后仍要按第 12.2.1节独立测试，严格邻域主张另用第 12.2.2节认证。训练损失降低没有直接证明证书半径增加。

### 12.3.2　跨环境风险与稳定依据的约束

局部约束没有重新加权环境，也未判定跨环境依据。若困难群体仍被平均忽略，或预测关系变化，我们需要保持损失定义，同时扩大模型负责的环境与关系。

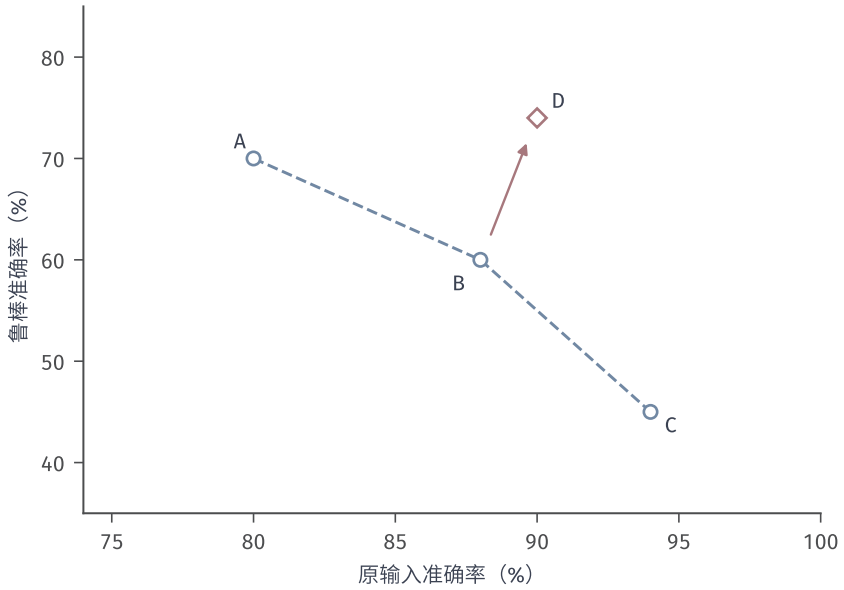


图 12.4 固定 100 个教学样本和标签保持邻域，原输入、鲁棒正确数依次为 A 80/70、B 88/60、C 94/45、D 90/74。鲁棒正确是原正确子集，D 两项优于 B。虚线仅连 A、B、C，不是实验或普遍最优边界；比较还需共同扰动及搜索条件。

允许分布族 $\mathfrak{Q}$ 需先按任务规定，例如容许已声明环境的比例改变，或容许参考分布附近预设距离内的变化。**分布鲁棒优化**（distributionally robust optimization, DRO）比较族内最高风险，并从模型候选 $\mathcal{F}$ 中寻找降低这一风险的模型。此处监督学习目标为

$$\min_{f\in\mathcal{F}} \sup_{Q\in\mathfrak{Q}} \mathbb{E}_Q \ell(f(\boldsymbol{x}), y). \tag{12.7}$$

它将每个候选模型在允许分布族内的最高期望损失作为比较依据（可参考第一卷“策略的价值与优化”章的“策略的轨迹价值与风险”一节中的“概率约束与模型不确定性”小节）。采用这一训练或压力目标所得的模型仍需独立测试，目标值本身没有给部署程序提供证书。若要概率上界，则需从抽样来源明确的 $S=\{(\boldsymbol{x}_i,y_i)\}_{i=1}^n$ 构造 $\widehat{\mathfrak{Q}}(S)$，用独立资料或预设统计规则选距离、矩约束、半径或组，并证明真实分布以声明概率在其中；经验推广与内层近似误差也需控制。过小漏变化，过大包含无意义压力，可积性、上确界取得或近似方式均影响保证。

若只允许若干组分布的任意混合，最不利分布会集中于最高风险组，式 (12.7)便成为最大组风险最小化。它防止大组压过小组，却没有消除组内泛化误差。Sagawa 等说明过参数模型可同时拟合训练组，最坏组泛化仍需正则和验证[9]。

[9] S. Sagawa, P. W. Koh, T. B. Hashimoto, P. Liang, *Distributionally Robust Neural Networks for Group Shifts: On the Importance of Regularization for Worst-Case Generalization* In International Conference on Learning Representations, 2020

设共有 $G$ 个组，组 $g$ 的分布为 $\mathcal{P}_g$，组内风险为 $R_g(f) = \mathbb{E}_{\mathcal{P}_g}\ell(f(\boldsymbol{x}), y)$。混合比例 $q_g \geq 0$ 且 $\sum_g q_g = 1$ 时，混合风险为 $\sum_g q_g R_g(f)$。允许任意比例时，将全部权重放到最大风险组即取得上确界：

$$\sup_{\boldsymbol{q}\in\Delta_G} \sum_{g=1}^{G} q_g R_g(f) = \max_{1\leq g\leq G} R_g(f), \tag{12.8}$$

$\Delta_G = \{\boldsymbol{q} \in \mathbb{R}^G : q_g \geq 0, \sum_g q_g = 1\}$ 有 $G$ 个概率分量、仿射维数 $G-1$。示例 12.1的平均目标主要由 99% 常见模板决定，最大组目标则首先看 50% 少见模板错误。

计算可交替增加高损失组权重与更新模型；只允许当前比例附近的混合，可减少极端保守。粗分组漏组内捷径，细分组增加小样本波动，组标签也未必可得。按高损失自动分组可能混入标注错误，需另做诊断，目标本身不能识别合法困难群体。

组风险低不等于机会或成本分配合理，组错误相同也可能同样很差。第 13章先确定分配原则，再选有意义的差异。本节组 DRO 仅在既定损失和组上优化，不据此声称公平。

多个环境还可提供共同稳定依据，前提是它们足以打破不稳定关系。第 9.3节讨论由不变性到目标域保证的条件，仅有训练一致性仍不支持任意新环境。

不变风险最小化寻找一种表示，使同一预测规则在多个环境都适用；组 DRO 只约束最大损失，没有要求最优规则一致。所有训练环境中模板与标签同向时，前者也可能接受捷径；各环境目标本来不同，强求共用规则还会丢信息。

受控比较需要认真调优的经验风险最小化参照。DomainBed 在七个多域数据集、统一实现下比较九种基线与三类选择准则，论文报告 ERM 在这些设置达到当时领先的目标域准确率[10]。方法名称本身没有替代训练和验证公平性。

这一结果只限制所比较设置，未说明 ERM 在所有变化最优。评价鲁棒目标应固定架构、预算、增强和可见验证环境，才能定位收益是否来自目标。第 9章确定信息何时可识别，受控实验再检查算法是否有效利用它。

[10] I. Gulrajani, D. Lopez-Paz, *In Search of Lost Domain Generalization* In International Conference on Learning Representations, 2021

### 12.3.3 超出适用范围时的拒绝策略

信息不足以覆盖所有输入时，可以增加接纳条件，收窄自动预测。拒绝增强的是系统应对，而非被拒输入上原模型的正确性；处理量减少和人工负担应与模型收益分别保存。

**最大类别概率**（maximum softmax probability, MSP）直接以最大预测概率作熟悉程度分数，低于阈值便拒绝。Hendrycks 与 Gimpel 将其用作错误与分布外检测基线，无需另训模型[11]。

MSP 只看类别相对差异。构造分数 $(10, 9)$ 与 $(1, 0)$，softmax 最大值同为约 0.731，因为两者差相同；它们的未归一化分数幅度不同，MSP 却无法区分。未知类别须另定语义和测试分布，原类别校准还未验证这种陌生程度。

若要保留归一化前信息，可以从 $K$ 类实值分数 $z_k(\boldsymbol{x})$、温度 $T > 0$ 构造**能量分数**（energy score）：

$$E_T(\boldsymbol{x}) = -T \log \sum_{k=1}^{K} \exp\left(\frac{z_k(\boldsymbol{x})}{T}\right). \tag{12.9}$$

常以较高能量作域外信号。Liu 等比较直接检测及训练中拉开域内、域外能量的方案[12]。

$T = 1$ 时上述向量能量约 $-10.313$ 和 $-1.313$，能够区分，却尚未证明区分对应未知程度。所有类别加同一输入相关常数会改变能量而保留概率，分类训练没有唯一识别输入密度。阈值需对实际模型验证，未经生成拟合的能量不能当真实负对数密度。

有辅助异常数据时，**异常暴露**（outlier exposure, OE）在正常损失外约束任务外输入。一种分类实现令异常预测接近均匀，以减少对其尖锐判类[13]。

辅助异常并未代表全部未知来源。相同来源用于训练与测试时，模型可能只学来源线索。应留出新的异常类别和来源，并在测试前固定各组。对邮件任务，可以把未见诈骗模板来源列为与域内相似的备择，把非邮件文档列为差异明显的备择；这两组只是预先选定的检验来源。按第 12.2.3节冻结阈值独立检验后，分别报告各组被误接纳的比例。

### 12.3.4 利用新环境信息时的风险与验收

新环境提供的数据可能支持重估统计量、部分更新或使用模型标签。**测试时适应**（test-time adaptation）由此改变运行状态；算法和训练过程交由第四卷“范式”的“知识的演进与迁移”部分，这里检查更新怎样改变主张及验收条件。

无标签适应依赖置信、一致性等代理，代理改善未必降低任务风险，错预测可能被强化，常数分类也可能显得稳定。限制参数、步长和样本减小影响，没有证明方向正确。少量真实标签可得时，应优先核验任务，而不只检查代理。

[11] D. Hendrycks, K. Gimpel, *A Baseline for Detecting Misclassified and Out-of-Distribution Examples in Neural Networks* In International Conference on Learning Representations, 2017

[12] W. Liu, X. Wang, J. D. Owens, Y. Li, *Energy-based Out-of-distribution Detection* In arXiv preprint arXiv:2010.03759, 2020

[13] D. Hendrycks, M. Mazeika, T. Dietterich, *Deep Anomaly Detection with Outlier Exposure* In International Conference on Learning Representations, 2019

批次、顺序、先预测还是先更新、何时重置，会让相同输入面对不同状态，均属于程序定义。打乱后的离线适应不代表时间相关服务，只评价高置信更新子集也遗漏其他输入和困难组。

冻结对照与适应程序应使用同一时间流和预算，报告新旧环境风险、变化轨迹、关键组、回退效果以及更新和状态保存成本。部署前还需确定新环境容限、相对参照在旧环境和关键组允许的增量、连续越界窗口数、回退版本与复验资料。总体平均收益不能抵消严重短窗口退化，新环境收益也不能隐去旧能力遗忘。

标签不足以判方向时，可保留参照、收窄范围或回退，以限制继续优化代理的损害。这些处置未证明适应成功。版本、更新规则、状态和验收条件共同固定，才能把结果归于完整适应程序。

## 12.4 本章小结

本章把变化后的模型表现与证据不足时的系统止损分开。测量扰动、群体比例与标签规律规定测试条件，边界、既有组错误和捷径解释失效。受控损坏、跨来源测试和局部证书各有范围，检测、拒绝和回退另评价止损；一种证据不能替代其余判断。

增强、局部稳定训练、最大组风险与适应改变不同对象。前几者用已有资料约束行为或加权风险，适应用新环境信息更新状态，也承担积错与遗忘。与调优基线比较后，仍要同时检查原环境、新环境、关键组与资源代价，更新证据不足则限制使用。

开篇误拦可以先按测量、比例或标签关系定位变化，再查边界、原有群体错误和模板依赖，取得对应补救信息。若损失集中到某人群，还需评价分配是否合理，下一章由公平原则检查机会、错误和负担。模型究竟用了哪些因素，则由第 15章进一步提供解释与核验。

**延伸阅读** 常见损坏基准与 WILDS 分别提供受控扰动和真实来源差异的证据。对照阅读时保留类型、划分及模型选择条件，就能确定基准平均结果适用到哪里[14,15]。

TRADES 与组 DRO 分别针对局部稳定和最大组风险；测试时适应的状态、算法与实践继续在第四卷“范式”的“知识的演进与迁移”部分展开[16,17]。

[14] D. Hendrycks, T. Dietterich, *Benchmarking Neural Network Robustness to Common Corruptions and Perturbations* In International Conference on Learning Representations, 2019

[15] P. W. Koh, S. Sagawa, H. Marklund, S. M. Xie, M. Zhang, A. Balsubramani, W. Hu, M. Yasunaga, R. L. Phillips, I. Gao, T. Lee, E. David, I. Stavness, W. Guo, B. Earnshaw, I. Haque, S. M. Beery, J. Leskovec, A. Kundaje, E. Pierson, S. Levine, C. Finn, P. Liang, *WILDS: A Benchmark of in-the-Wild Distribution Shifts* In Proceedings of the 38th International Conference on Machine Learning, 2021, pp. 5637–5664

[16] H. Zhang, Y. Yu, J. Jiao, E. P. Xing, L. El Ghaoui, M. I. Jordan, *Theoretically Principled Trade-off between Robustness and Accuracy* In Proceedings of the 36th International Conference on Machine Learning, 2019, pp. 7472–7482

[17] S. Sagawa, P. W. Koh, T. B. Hashimoto, P. Liang, *Distributionally Robust Neural Networks for Group Shifts: On the Importance of Regularization for Worst-Case Generalization* In International Conference on Learning Representations, 2020

第 13 章

# 公平性

培训名额模型总体预测准确，却可能集中拒绝某一群体的合格者。我们要评价这个后果，既需看错误落在哪些人身上，也需先确定名额应怎样分配。各组准确率相同，仍可能有不同误拒、误收、机会数量和实际损失。

前两章已经提供了错误和环境条件的证据，还没有给出人之间的分配原则。预测可靠或稳定不能决定机会、负担怎样才合理，公平性需要在这些证据之上声明自己的要求。

在第 10章的三层框架中，公平要求先确定比较哪些待遇、错误和影响路径；群体统计、个体对照、因果分析与内容评价再提供证据。群体构成、标签产生和长期后果改变时，还需监测、复查与纠正，使结论在生命周期中保持限定范围。

本章以名额分配研究保护对象、判定证据和干预。先从具体待遇及形成原因建立比较对象，再把保护维度转为准则与检验，最后定位数据、训练、决策中的修改。准则决定要改善什么，机制决定改哪里，即时效果和长期反馈再检验措施是否真正改善后果。

图 13.1固定两人的认可资格。教学设定假定三个项目已经覆盖全部分配依据，也没有许可的抽签机制；若无关差异稳定地产生不同待遇，就违反这一场景的个体一致性。现实审计还需验证资格充分和随机机制等条件，材料看似相近本身不够。

## 13.1 模型的公平性

### 13.1.1 公平性的含义

**公平性**（fairness）依据任务认可的原则，评价模型与流程怎样在不同人之间分配机会、收益、错误和负担。除了谁获得什么，还需检查决定依据及纠正待遇的途径。适用同一准则，并不要求所有人的输出都相同，必须先说明哪些差异合理，哪些违背保护要求。

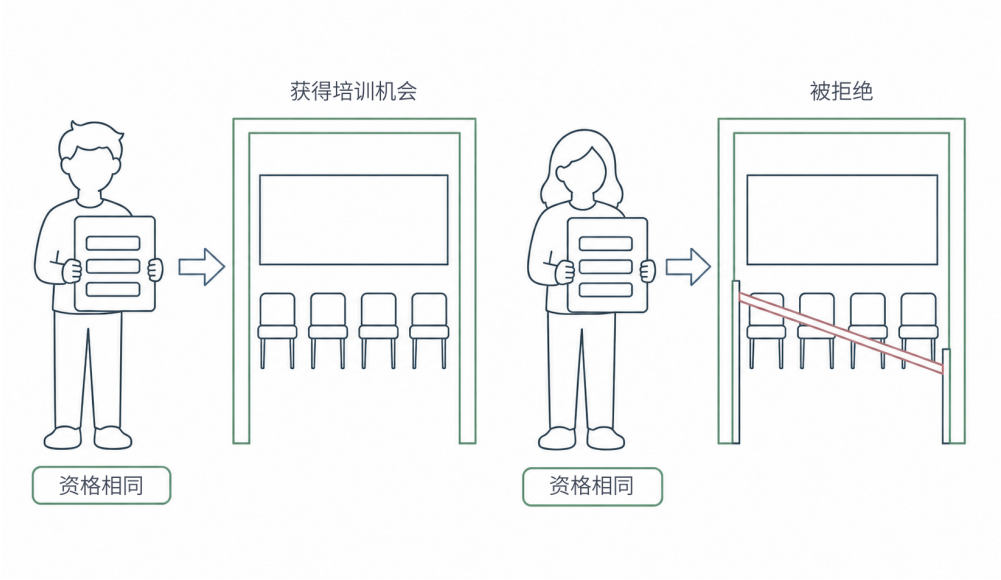


图 13.1 同一系统处理两个认可资格相同的申请者，材料上的三个相同资格项覆盖教学设定的分配依据，一人获选、一人被拒，提示调查个体差别。人物外观只区别对象，未指定差异原因。图为构造情景。

现有资格、培训预期收益和弥补机会不足，是三种可能的名额原则，可能产生不同名单。准确率无法选出唯一合理原则。规范判断先确定允许和应纠正的差异，统计方法随后检查要求，二者职责不同。

为把资格与机会分开，记可用非群体特征 $\boldsymbol{x}$、关注属性 $a$、资格标签 $y \in \{0,1\}$ 及决策 $\hat{y}$。部署读取 $a$ 时，合格概率分数为 $S = p(\boldsymbol{x}, a)$，否则为 $S = p(\boldsymbol{x})$；决策分布相应记 $q_{\boldsymbol{x},a}$ 或 $q_{\boldsymbol{x}}$，确定性决策是退化分布。审计仍可按 $a$ 分组，不等于预测使用 $a$。培训例中 $y = 1$ 为按认可标准合格，$\hat{y} = 1$ 为获选，历史录取不能直接充当资格。邮件的正决策表示隔离，此处表示机会，错误方向必须随含义解释。

样本人数、预测分数、录取决定、参加成本和最终收益属于不同环节。同概率经不同阈值可获得不同机会，同机会经不同费用与服务可得到不同收益。系统边界需包含这些环节，局部均等尚未评价完整后果。

### 13.1.2 不公平的表现

构造两组各 20 名同标准合格者，一组获选 18 人，另一组 10 人。若要求群体身份不改变合格者机会，不同误拒便需解释和纠正。只有总体录取率而缺资格标准时，却还无法据此判定不合理待遇。

群体汇总也可能漏个体差别。两名申请者的所有认可条件相同，只因无关地区标签稳定获得不同机会，即使地区总录取率相同仍违背个体要求。资格不同者的处理则需回到标准，不能仅要求输出一致。

**分配性伤害**（allocative harm）发生在名额、资金或服务分配，**表征性伤害**（representational harm）发生在刻板描述、忽视或贬低。推荐数量相同而无依据地把某组描述为不适合技术岗位，机会计数没有检验这种表达。更多证明、等待和申诉也是服务负担，最终比例相同未必消除它们。

Gender Shades 按研究定义的肤色与性别标注交叉审计商用图像性别分类器，Buolamwini 和 Gebru 报告各交叉组的错误差异，展示了拆分评价的必要性。结论限于当时系统、样本与标签；肤色并非无误种族代理，图像性别标注也没有表达完整性别身份[1]。

这些表现分别指向分配与负担、错误、个体和表征，为判定选择了对象。原因却可能不同，接下来需要沿过程定位，才能选择干预。

[1] J. Buolamwini, T. Gebru, *Gender Shades: Intersectional Accuracy Disparities in Commercial Gender Classification* In Proceedings of the 1st Conference on Fairness, Accountability and Transparency, 2018, pp. 77–91

### 13.1.3 不公平的形成原因

任务目标本身可能造成差异。历史录取若被当作资格，模型学习的是过去筛选，即使忠实复现标签，也未满足当前认可标准。增加同类记录无法纠正目标含义，需先重新规定预测与决策用途。

采集遗漏、测量不等价与标签偏差需要分别处理。只通过线上报名采样，可能遗漏难以完成报名的人；语言测验的难度可能被误计为能力差异；标注判据不一致也可能造成组间误差。针对缺少的人群补充可靠、独立的观测，可以缓解样本不足，却未必修复测量与标签问题。

总体平均训练可用多数收益抵消小群体损失。删除群体字段也未消除代理信息，地区与资源关联仍可传递差异。依据是否允许，要看任务原则和路径；审计、训练约束及直接决策的属性使用分别记录，不能以“不读取群体”代替公平证据。

部署阈值将分数变成待遇。统一阈值未必均衡错误，分组阈值也未必满足个体要求，人工、收费与等待还会增加模型外负担。只改预测器而保留有问题流程，后果可能继续存在。

培训机会还改变数据：只有获选者有成绩，**选择性标签**（selective labels）便表示结果可见性取决于过去决策。后续训练缺少被拒者证据，分配又可能改变能力和资源。需要额外观测或识别假设，更换既有记录上的指标不能补齐这些信息。

我们用形成原因定位环节，用公平要求判定该环节是否合理。例如只改邮政编码引起预测变化，说明模型依赖该输入，却未判定合理性；输出不变也未排除其他代理。第 15.3节提供更系统的解释，机制线索仍要与保护对象、原则和证据结合。

## 13.2 公平性的判定

判定先问保护哪种后果，再写应成立的关系，最后设计检查。例如保护合格者机会，可以要求真正例率相同，并用组内合格获选比例及误差估计检验。维度、准则和证据三者各有作用，算法名称无法替代它们。

机会与负担、预测错误与分数含义、相似个体的待遇、影响路径和社会表征分别给出五类比较对象。前两类用群体统计，个体用成对证据，路径用因果关系，表征用内容和受控对照。各分支建立对象、准则、方法与边界，之后再处理共同的准则冲突与证据强度。

### 13.2.1 机会与负担的分配

机会分析要先确定目标人群和分配单位，再比较获得量与申请、使用成本。培训申请的分母应覆盖已声明范围，若只统计完成线上报名者，可能把入口处排除者漏掉。

若要求各组所有申请者的机会比例相同，不按资格条件化，可使用**人口统计均等**（demographic parity）。待比较属性值 $u, v$ 均有正概率时要求

$$\mathbb{P}(\hat{y} = 1 \mid a = u) = \mathbb{P}(\hat{y} = 1 \mid a = v).$$

它保护总体分配而不使用资格标签。标签不符认可标准时可以避免依赖标签；资格差异应被考虑时，则需另说明为何仍采用比例相同。

录取率 0.02 与 0.04 的绝对差是两个百分点，同口径 100 人约差 2 个名额，相对比例却为一半。报告差或比都需基准，实际受影响人数还需规模与参照率。绝对量和相对量表达不同后果。

在相同任务与时段保存组别、机会、等待和费用。组内获选除组内人数得到机会率，差或比比较群体；平均、分位或超限比例比较负担，容差由第 13.2.6节的责任流程确定。最终比例相同而申诉更多时，两类结论仍不同。

总体机会率没有定位原因，也没有比较同资格者，下一小节需补标签与错误。若疑虑是大组内部集中受损，则先细化人群而保留当前指标。

**交叉群体中的细化检验** 构造两个二元属性形成等大四组，录取率依次 0.9、0.1、0.1、0.9。单属性分组都为 0.5，交叉组差却 0.8。Kearns 等将粗组通过而结构子群违规称为公平性划分操纵（fairness gerrymandering），研究同时审计与学习；名称描述聚合掩盖，不要求人为故意[2]。

[2] M. Kearns, S. Neel, A. Roth, Z. S. Wu, *Preventing Fairness Gerrymandering: Auditing and Learning for Subgroup Fairness* In Proceedings of the 35th International Conference on Machine Learning, 2018, pp. 2564–2572

要细化比较，先设预定或复杂度受限的判别族 $\mathcal{G}$，$g(\boldsymbol{x}, a) = 1$ 表示子群。**子群公平**（subgroup fairness）还需相同参照人群 $C$，人口统计均等取全体申请者，假正例比较取 $C = \{y = 0\}$，且 $\mathbb{P}(C) > 0$。定义

$$\begin{aligned} r_C &= \mathbb{P}(\hat{y} = 1 \mid C), \\ \alpha_C(g) &= \mathbb{P}(g = 1, C), \\ r_C(g) &= \mathbb{P}(\hat{y} = 1 \mid g = 1, C) \quad \text{当} \alpha_C(g) > 0. \end{aligned}$$

$r_C$ 是参照正决策率，$r_C(g)$ 是子群率；$\alpha_C(g)$ 是全体目标分布中 $g = 1$ 与 $C$ 联合事件质量，不是 $\mathbb{P}(g = 1 \mid C)$。用质量加权率差，并对全部候选要求

$$\begin{aligned} \upsilon_C(g) &= \begin{cases} \alpha_C(g)\,|r_C(g) - r_C|, & \alpha_C(g) > 0, \\ 0, & \alpha_C(g) = 0, \end{cases} \qquad (13.1) \\ \sup_{g \in \mathcal{G}} \upsilon_C(g) &\le \gamma, \qquad \gamma \in [0, 1]. \end{aligned}$$

$\gamma$ 为预设容差，零质量组的分段定义避免无定义条件率。质量权重降低极小组的总体贡献，也可能掩盖小组的大原始差，因此两者及组大小都要报告。

审计器搜索 $\mathcal{G}$ 中最大的 $\upsilon_C(g)$，独立资料再确认，不能改成仅搜索原始率差。粒度细化仍沿用所选机会或错误率，改变 $C$、容差或族则形成新要求。遗漏真实受损组或搜索不足，会使无违规结果不充分。确认一个候选，只能支持该候选的违规结论。要支持全族达标，还需对约定判别族统一控制估计误差，并给出搜索完备性或近似最优保证。所用保证依赖的复杂度、最小质量等条件也须声明。

### 13.2.2 预测错误与分数含义

相同机会量可能由不同错误产生。我们现在用可信资格标签检查组内错误水平及同分数含义。如果标签已经偏离认可的资格标准，精确率比较的仍是预测与这些偏差标签的吻合程度，无法直接回答合格者是否受到不同待遇。

要保护合格者的机会，可要求**机会均等**（equal opportunity），即各组真正例率一致；再要求假正例率一致，便是**均等化赔率**（equalized odds）。比较的组与标签联合事件都有正概率时，条件为

$$\mathbb{P}(\hat{y} = 1 \mid y = b, a = u) = \mathbb{P}(\hat{y} = 1 \mid y = b, a = v), \quad b \in \{0, 1\}. \qquad (13.2)$$

标签承担了资格判据，适用性也依赖其含义。Hardt 等讨论这种统计判定及固定预测器后处理，同时指出联合统计量的边界[3]。

[3] M. Hardt, E. Price, N. Srebro, *Equality of Opportunity in Supervised Learning* In arXiv preprint arXiv:1610.02413, 2016

第 11章校准的是同分数事件频率。公平审计可再要求各组部署分数 $S$ 满足 $\mathbb{E}[y \mid S, a] = S$，在每个正概率组的分数支持上几乎处处成立。$S$ 可由 $p(\boldsymbol{x}, a)$ 或 $p(\boldsymbol{x})$ 产生，审计属性 $a$ 只承担条件化用途。这保护同分数的解释，并未要求机会或错误率相同。

**正预测值均等**（predictive parity）则把分母换为各组已获选者，要求其中合格比例相同，正决策事件有正概率才定义。它不同于合格者中的获选率，也不同于逐分数校准。

条件位置可揭示保护对象。人口统计均等为 $\hat{y}$ 与 $a$ 独立，均等化赔率为给定 $y$ 后二者独立；给定 $\hat{y}$ 比较 $y$ 与 $a$ 则看同决策的资格解释，正决策部分即正预测值。申请者关注同资格机会，分配方可能关注获选质量，两种视角应说明其任务理由。

**按标签与分数进行检验** 组内无正例时真正例率无定义，不能填零并当作最差表现。每项条件率都先检查分母，缺证据与差表现需要分别记录。

> **示例 13.1 同一批申请者上的不同公平指标** 构造两组各 100 人，合格人数 20 和 60，获选合格人数 16 和 48、获选不合格人数 8 和 4。机会率为 $24/100 = 0.24$ 与 $52/100 = 0.52$，真正例率 $16/20 = 0.8$ 与 $48/60 = 0.8$，假正例率 $8/80 = 0.1$ 与 $4/40 = 0.1$，正预测值 $16/24 \approx 0.667$ 与 $48/52 \approx 0.923$。
>
> 同一构造计数满足均等化赔率，两项差为零，却有人口统计机会差 0.28 和正预测值差约 0.256。必须注明是哪项相同，不能统称群体一样公平。这些是样本比例，未来总体还需估计误差。

图 13.2分别对照全体机会、同资格机会和获选资格。相同 $t, f$ 仍保留两组不同资格比例，所以另外两项不相同。第 13.2.7节进一步推导这种基准比例引起的限制。

图 13.3按资格与决策交叉计数。观察分母，就能判断指标保护全体、合格者、不合格者还是获选者。

混淆矩阵没有个人概率，不能检验分数。另构造两组各 10 人得 0.8 分，合格数 8 与 6，则组内经验频率为 0.8 和 0.6，第二组的经验频率比预测分数低 0.2。这可以与前例总计数并存，说明同错误率未包括分数信息。总体校准是否失败，还要根据样本支持估计误差。

按准则保存矩阵与分数：获选除总人数、合格获选除合格人数、合格获选除获选人数，分别对应机会、真正例率和预测值。校准再按组及分数区间比较均值与频率。条件和分母不同使同一记录回答不同问题，达标对照还需第 13.2.7节的误差。

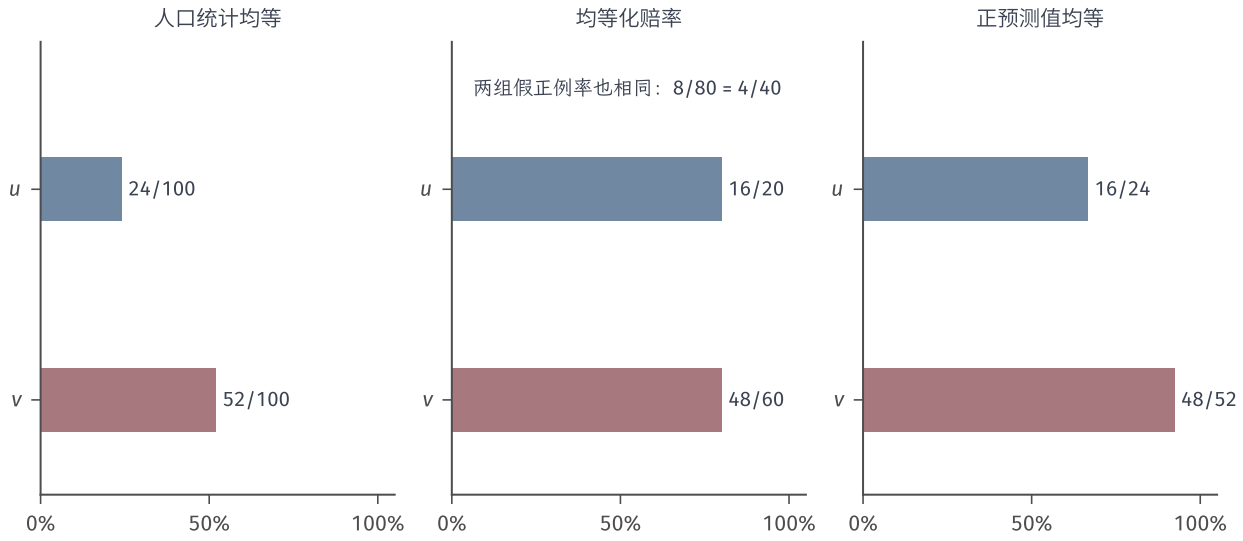


图 13.2 同一教学记录按三个分母比较：全体申请者、同资格者、已获选者。两组各 100 人，合格 20 与 60，计数沿示例 13.1。共同 $t = 0.8, f = 0.1$ 满足均等化赔率，其他两项比例仍不同。冲突限于不同基准比例及 $0 < f < t < 1$，$f = 0$ 等另作分析。

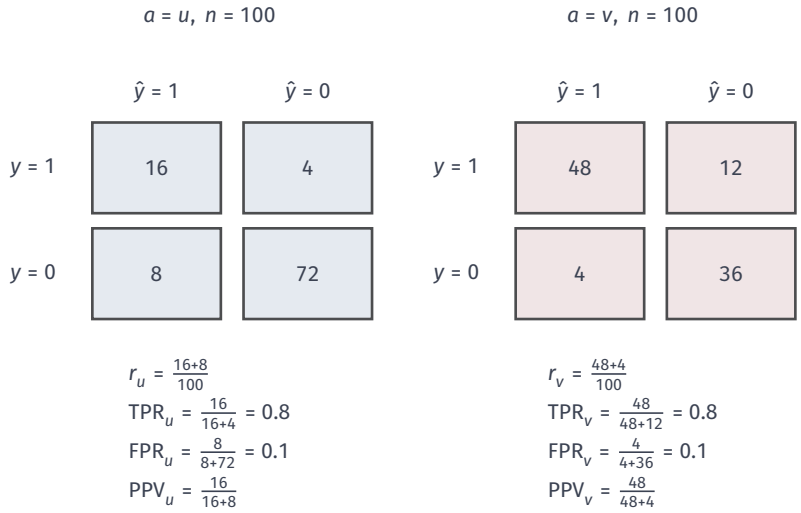


图 13.3 按资格为行、是否获选为列排列示例 13.1两组计数，下方指标各取相应分母。真正例和假正例一致仍可伴随机会及预测值不同。计数未包括概率，不能检验分数校准。

**交叉群体中的分数检验** 第 13.2.1节细化比较群体的思路也用于概率。**多重校准**（multicalibration）要求在可识别子群的各分数区间内，平均预测分数与实际事件频率的差不超过给定容差，Hébert-Johnson 等用它限制总体校准漏掉的复杂组偏差[4]。

[4] Ú. Hébert-Johnson, M. Kim, O. Reingold, G. Rothblum, *Multicalibration: Calibration for the (Computationally-Identifiable) Masses* In Proceedings of the 35th International Conference on Machine Learning, 2018, pp. 1939–1948

沿第 11.2节分箱，先设最小概率质量下的候选 $\mathcal{A} \subseteq \mathcal{G} \times \mathcal{B}$，$\mathcal{B}$ 为区间族。我们比较每个组区间中的平均残差，并要求全部不超容差：

$$\sup_{(g,B)\in\mathcal{A}} \left|\mathbb{E}[y - S \mid g(\boldsymbol{x}, a) = 1,\ S \in B]\right| \le \varepsilon. \tag{13.3}$$

经验均值估计条件期望，全族结论要统一误差范围，搜索后只确认一个候选仍限于该候选。要求防止持续高估低估，并未要求各组成功率一致。

### 13.2.3 相似个体的处理差异

群体平均不足以保护每对相近者。**个体公平**（individual fairness）要求任务相关条件相近的人得到相近处理，距离及认可因素因而成为定义的一部分。

Dwork 等以相似性界表达这一关系。完整审计状态 $\boldsymbol{z} = (\boldsymbol{x}, a)$ 属于 $\mathcal{Z}$，任务先决定哪些分量可计入距离，记录 $a$ 不表示可据它区别待遇。令 $q_{\boldsymbol{z}}$ 为决策分布、$d$ 为任务认可差异、$D$ 为决策分布差异，对全部个体对要求

$$D(q_{\boldsymbol{z}}, q_{\boldsymbol{z}'}) \le d(\boldsymbol{z}, \boldsymbol{z}'). \tag{13.4}$$

二元规则用总变差时，$D$ 就是录取概率绝对差，这使“相近处理”可以量化[5]。

距离 0.05 的两人若概率 0.9 和 0.1，违反界；若 0.60 和 0.63，这一对达标。距离仍需规范依据，历史收入若含过去机会不平等，纳入距离可能把不平等当合理差异。结论只相对于该距离。随机化保护事前分布，同等人一次抽签仍可能结果不同。

检验先冻结距离和分布估计，搜索 $D(q_{\boldsymbol{z}}, q_{\boldsymbol{z}'}) - d(\boldsymbol{z}, \boldsymbol{z}') > 0$ 的个体对。如果接口直接给出决策概率，就可以计算相对于式 (13.4)的这一超限值；如果只能重复调用随机接口，则需估计概率并给出误差区间。有限个体对中没有找到反例，只支持已检查范围内的结论，报告还应说明搜索范围和发现的最大超限值。群体准则通过，不能推出全部个体对都通过。

构造两组各一高资格一低资格，第一组只选高、第二组只选低，机会率均一半却违背同资格待遇。反过来，各组高资格比例不同而规则选全部高资格，若同资格距离 0、异资格距离 1，式 (13.4)可成立，机会率仍不同。两准则保护的关系因而互不推出。

### 13.2.4 决策依据与影响路径

关注禁止因素怎样传递影响时，需要因果模型。反事实公平（counterfactual fairness）固定同一个体的外生背景，再比较不同群体属性干预下的预测，而非直接配对现实中的两人；Kusner 等据此给出定义[6]。

[5] C. Dwork, M. Hardt, T. Pitassi, O. Reingold, R. Zemel, *Fairness Through Awareness* In Proceedings of the 3rd Innovations in Theoretical Computer Science Conference, 2012

[6] M. J. Kusner, J. R. Loftus, C. Russell, R. Silva, *Counterfactual Fairness* In Advances in Neural Information Processing Systems, 2017

令 $\boldsymbol{U}, \boldsymbol{X}, A$ 为外生背景、观测和属性，取值为 $\boldsymbol{u}, \boldsymbol{x}, a_0$；此处 $\hat{Y} \in \{0,1\}$ 表示是否给予机会的二元决策。$\hat{Y}_{A \leftarrow v}(\boldsymbol{U})$ 表示属性设为允许值 $v$ 后的决策。要求对事实分布 $P_{\boldsymbol{X},A}$ 几乎处处的 $(\boldsymbol{x}, a_0)$，全部 $b \in \{0,1\}$ 与允许的 $v$ 满足

$$\begin{aligned} &\mathbb{P}\big(\hat{Y}_{A \leftarrow a_0}(\boldsymbol{U}) = b \mid \boldsymbol{X} = \boldsymbol{x}, A = a_0\big) \\ &\quad = \mathbb{P}\big(\hat{Y}_{A \leftarrow v}(\boldsymbol{U}) = b \mid \boldsymbol{X} = \boldsymbol{x}, A = a_0\big). \end{aligned} \tag{13.5}$$

事实观测先推断外生背景，同一机制再生成干预世界。只改一列却固定其后果，没有完成这种反事实传播（可参考第一卷“因果响应”章的“反事实公平”定义）。

构造属性 $a \in \{0,1\}$、能力 $u$ 和测验 $x = u + \gamma a$，若 $\gamma a$ 路径被认定不应影响分配，以测验 $x$ 作为决策依据就会保留这条属性影响；在结构正确的条件下，改用 $x - \gamma a = u$ 可以去掉该项影响。取 $\gamma = 2$，实际 $a = 1, x = 7$ 推出 $u = 5$；设 $a = 0$ 后应有 $x = 5$，校正分数在两世界都 5。保留 $x = 7$ 只改 $a$ 没有传播结构。公平计算可能需要属性，但结构与系数不可靠时机械相减未必合理，观测分布通常不足以唯一识别它。

有些任务只禁部分路径，例如允许实际能力、禁止无关直接偏好，需要明确路径与识别条件。统一要求属性改后不变未必合适。第 15.5节寻找个体可实施的补救行动，本节属性干预仅用于机制分析，未将属性当应改变的行动。

审计需声明图与方程，依据事实推背景，对同背景生成不同属性下决策分布，再比较式 (13.5)。不能识别机制时，报告合理机制间的敏感性；混淆矩阵没有这种证据。计算相等也仅在因果模型成立时支持结论。

### 13.2.5 生成内容中的社会表征

培训建议还可能刻板描述、遗漏或无依据地贬低人群，录取计数无法评价这些内容。先规定表达及语境，例如证据不足时不用身份推断能力，再建立可核验标注。

受控任务固定资格、经历和请求，只改无关身份线索，比较描述、推荐、尊重及无依据断言。证据充分和不足都需测试，防止一律拒答的表面均等；文本自然性和事实含义也需核验，规则及人工复核评价输出。词替换只证明对应行为差异，未证明个体因果反事实。

随机生成需重复抽样，保存比例和波动，并在不同提示检查稳定性。评分者也可能产生偏差，因此需要用已核实标签的样本检查评分与这些标签是否一致，并分析常见误判；多人评分时，还应报告评分者之间的一致程度。BBQ 区分模糊和非模糊语境，提示内容评价需保留证据充分性及文化、语言范围[7]。

[7] A. Parrish, A. Chen, N. Nangia, V. Padmakumar, J. Phang, J. Thompson, P. M. Htut, S. R. Bowman, *BBQ: A Hand-Built Bias Benchmark for Question Answering* In Findings of the Association for Computational Linguistics: ACL 2022, 2022, pp. 2086–2105

### 13.2.6 公平要求的声明

要将上述证据用于判定，先写任务、人群、保护关系、资格标准、禁止路径与优先后果，再定主要准则、容差、效用和资源限制，说明验证数据与期限。指标名称只给一种测量，尚未形成完整公平要求。

要求还需责任依据。识别法律、政策与领域义务，保存受影响者、专家、运行方的意见及分歧，明确由谁批准准则、容差、最低水平、资源安排及属性用途。批准理由、未解决异议、纠正入口和复查周期应可追溯。这些程序不能消除价值冲突，但可以帮助区分机构偏好、观测到的比例与已经获得认可的规范依据。

教学系统可取独立资格为 $y$，预设两个群体真正例率绝对差不超 0.05、两组都至少 0.8，名额受预算约束，并报告假正例、交叉组和申请成本。数值是构造标准。差距约束限制两组之间的差异，最低水平要求则保护各组的合格者获选率。若仍有一组低于下限，只降低另一组的获选率并不能达标。资源与要求冲突，应重新讨论而非隐藏条件。

属性用途也进入声明。训练与审计用 $a$ 构造约束，不直接决定部署能否读取；后者由责任流程规定。分组阈值必须识别组别，训练约束却可能得到无需属性的预测器，允许用途决定候选方法。

意图与结果分开记录：目标说明打算满足什么，验收说明哪个版本在何人群、数据和假设下有何证据。独立检验未完、组样本不足或因果不可识别时保留限制，去偏算法名称无法证明公平。

### 13.2.7 判定结论的形成

五类证据分别对应要求，综合判定还需说明本次选择哪些准则、能否兼容、样本及假设支持到哪里。某分支通过只给局部结论，不能直接合成无条件“系统公平”。

**准则之间的取舍** 同一系统承担的准则可能相互冲突，指标分歧未必来自训练不够。下面由群体比例推导兼容条件，限定共同可选择的目标，而非增加一种审计方法。

例 13.1中，相同错误率仍产生不同机会。设正例比例 $\pi_a$、真正例率 $t_a$ 和假正例率 $f_a$，按资格分解机会率得到

$$r_a = \pi_a t_a + (1 - \pi_a) f_a.$$

若共用 $t, f$ 且 $t \neq f$，不同 $\pi_a$ 就给不同 $r_a$。在上述条件下再要求 $r_a$ 相同，就无法同时保持这两个共同错误率。

同样条件还决定获选者的资格。若共同真正例 $t$、假正例 $f$，各组 $\pi_a \in (0,1)$ 且正决策概率大于零，Bayes 公式给出

$$\mathbb{P}(y=1 \mid \hat{y}=1, a) = \frac{t\pi_a}{t\pi_a + f(1-\pi_a)}. \tag{13.6}$$

$t, f > 0$ 时右侧随 $\pi_a$ 严格增加，基准比例不同就无法同时共用正预测值。结论不依赖分类算法，却需保留边界：$f = 0$ 时预测值可能都 1。更一般的分数公平取舍也应连同条件理解[8]。

另一项冲突涉及分数。令部署 $S \in [0,1]$ 组内校准，且各组 $0 < \pi_a < 1$，记正负例平均 $\mu_{1,a} = \mathbb{E}[S \mid y=1, a]$、$\mu_{0,a} = \mathbb{E}[S \mid y=0, a]$。若分别跨组共用 $\mu_1, \mu_0$，全期望给出

$$\pi_a = \mathbb{E}[S \mid a] = \pi_a \mu_1 + (1-\pi_a)\mu_0.$$

不同基准比例两式相减得到 $\mu_1 - \mu_0 = 1$，有界分数迫使 $\mu_1 = 1, \mu_0 = 0$，即完美预测。因此非完美分数、不同基准比例下三项不能共存。平均分数平衡不是式 (13.2)的二元率平衡，条件不可混用。

冲突需要依据已记录规范和参与过程设优先级。例如优先避免误拒合格者，可用机会均等为主约束，同时公开假正例、名额与预测值的代价。没有优化的准则仍需报告，移出目标不等于其后果消失。

**有限样本与建模假设** 准则规定总体关系，有限数据只提供估计。群体受样本与分母限制，个体另受距离限制，反事实另受机制限制；后两项不会因更多样本自动正确。我们分别报告假设敏感性和抽样误差，再以群体差说明判定。

真正例分母是组内正例，假正例分母是组内负例，小交叉组可能缺证据，多组搜索也增加偶然极值。敏感属性若经补全，其估计误差同样进入审计，不能视作无误身份。

先在审计标签揭示前冻结模型、阈值、指标、容差和两组。审计数据不参与这些选择，各组正例分别独立同分布地来自目标人群的组内正例分布，其数量为 $n_u, n_v$，真正例率的估计记为 $\hat{t}_u, \hat{t}_v$。预设 $\delta \in (0,1)$，分别使用 Hoeffding 并联合控制，以至少 $1-\delta$ 有

$$|(t_u - t_v) - (\hat{t}_u - \hat{t}_v)| \le \sqrt{\frac{\log(4/\delta)}{2n_u}} + \sqrt{\frac{\log(4/\delta)}{2n_v}}.$$

一组正例少便使差距界宽，总样本多不能补偿。要求 $|t_u - t_v| \le \eta$ 时，需将经验绝对差加上误差界后仍不超 $\eta$；未拒绝零差不能证明差小。资料参与选模、调阈值、挑指标或搜索后，需独立审计或候选统一界，不能保留单次解释。

[8] J. Kleinberg, S. Mullainathan, M. Raghavan, *Inherent Trade-Offs in the Fair Determination of Risk Scores* In arXiv preprint arXiv:1609.05807, 2016

**达标、违反与证据不足** 相对容差，可靠上界仍在界内支持达标，下界已超界支持违反，范围跨界则证据不足。个体另给距离与搜索，因果另给机制，内容另给任务及评分。未发现违规或统计不显著，均不足以单独宣称公平。

报告保留各组水平、准则、数据和版本，同时指出未覆盖人群及假设。这才确定了干预要补的要求与情境，选择补采、重训或流程调整还要看形成原因。

## 13.3 公平性的干预

相同机会差可能由数据遗漏、资格标签、训练加权或决策规则产生。判定提供未满足的要求，机制提供修改位置，两者结合才能选择干预；差距本身没有指定某个算法。

下面按数据、训练和服务三个位置处理已声明要求。补充与核实数据、调整学习规则、改变把分数转成行动的规则，可以组合使用，但解决的问题不同。例如，补充少数群体的数据后，仍可能需要调整训练中的错误代价；训练约束通过后，也仍需检查申诉过程的等待时间。最后用即时与长期证据决定措施是否改善处境。

图 13.4沿数据、训练和决策画出干预位置。发生在其他位置的问题未必能由当前环节的指标调整修复，因此还要沿完整后果验收。

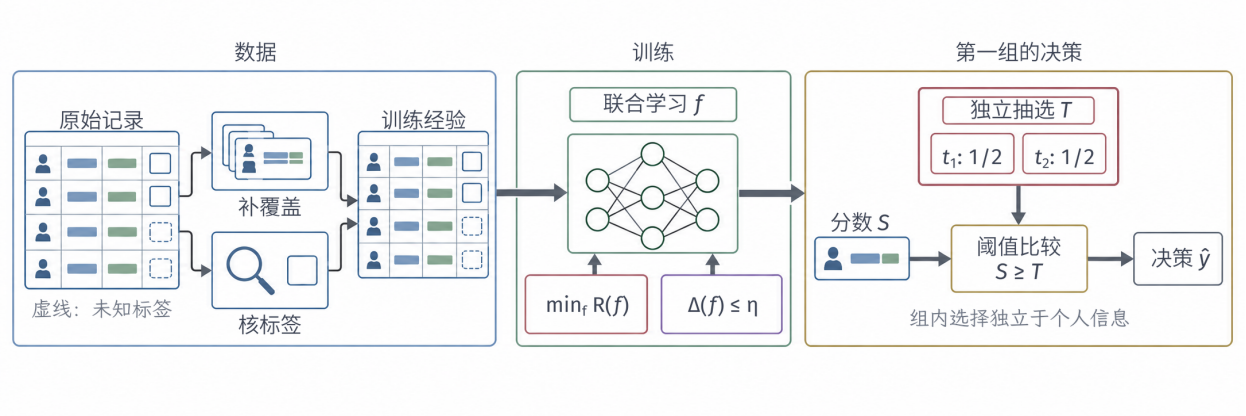


图 13.4 数据环节补充遗漏人群并核实标签，训练环节调整风险目标及公平约束；三个位置的措施可以组合。虚线记录标签未知。决策面板画示例 13.2中的第一组：按预设各半概率独立抽选阈值 $T$，再按分数 $S$ 是否达到 $T$ 产生决策 $\hat{y}$。组内抽选独立于个人分数、其他特征及真值，第二组采用固定阈值。单环节达标未保证系统全部要求。

### 13.3.1 数据采集与质量的改进

遗漏人群时，按任务、条件与交叉组定位缺少的语言、设备、地区或资格区间，再扩采集渠道。新增多少有效观测要对应之前哪个缺口，人数相同不是充分目标。重复旧样本只能改变训练频率，未增加独立个体信息。

训练可有意多采困难群体，评价则说明代表目标人口还是平衡审计人口。改比例会改变平均含义，分组结果仍须保留，必要时按有依据目标权重汇总。新审计资料独立于干预选择，才能避免反复调试后的选择偏差。

测量问题要核查同字段跨组含义，用语言、设备配对及可靠参照区分真实与测量差。标签问题要复核资格、指南和争议，必要时重标。修正错误或不合理目标须保留依据，不能为比例相同改写真实结果。

结果缺失不能填作失败。培训只观察获选者时，寻找独立资格测验、调查或其他可靠观测；改变选择取得证据要说明实施条件，统计修正则需概率和识别条件，见第 13.3.4节。更多获选记录未自动增加被拒者信息。

采集、测量与标签改变需随数据留痕。数据集说明书的用途、组成、采集和范围帮助定位人群遗漏和误用，记录却未替代实际补采及核验[9]。

[9] T. Gebru, J. Morgenstern, B. Vecchione, J. W. Vaughan, H. Wallach, H. Daumé III, K. Crawford, *Datasheets for Datasets* In arXiv preprint arXiv:1803.09010, 2021

改好数据仍未决定分配原则。训练若继续用多数收益抵消小组损失，需要改学习规则；分数转行动仍有问题，则转到服务流程检查。

### 13.3.2 训练目标与学习规则的调整

已有依据被模型不合理使用时，可改样本错误代价、约束表示信息或直接约束公平指标。三者都在训练中起作用，但分别改变样本对损失的贡献、表示保留的信息，以及学习器对公平准则违反程度的响应，需要按形成原因选择。

令训练数据 $\mathcal{D}_{\mathrm{tr}}$、候选 $\mathcal{F}$ 确定经验风险 $\widehat{R}_{\mathrm{tr}}(f)$ 和选定差异 $\widehat{\Delta}_{\mathrm{tr}}(f)$。先在差异容限 $\eta$ 内比较风险，得到

$$\begin{aligned} \min_{f \in \mathcal{F}} \quad & \widehat{R}_{\mathrm{tr}}(f) \\ \text{subject to} \quad & \widehat{\Delta}_{\mathrm{tr}}(f) \le \eta. \end{aligned}$$

目标总体的 $R(f), \Delta(f)$ 需独立审计。惩罚 $\widehat{R}_{\mathrm{tr}} + \lambda \widehat{\Delta}_{\mathrm{tr}}$、$\lambda \ge 0$ 便于求解，固定系数仍未证明约束满足。

图 13.5在构造 200 人资料中同时比较准确率与真正例率绝对差。准确率不低、差距不大且至少一项严格改善时，候选支配另一候选；当前未被支配者形成有限帕累托集合（Pareto set）。换候选、指标或评价资料会改变这个集合，不能看作普遍边界。

**不同样本与错误的训练代价** 为让两组各占经验损失一半，训练人数 $n_u, n_v > 0$、总 $n = n_u + n_v$ 时，可给组 $a$ 每样本权重 $\omega_a = n/(2n_a)$，得到

$$\frac{1}{n}\sum_{i=1}^{n} \omega_{a_i} \ell(f(\boldsymbol{x}_i), y_i) = \frac{1}{2}\hat{R}_u(f) + \frac{1}{2}\hat{R}_v(f),$$

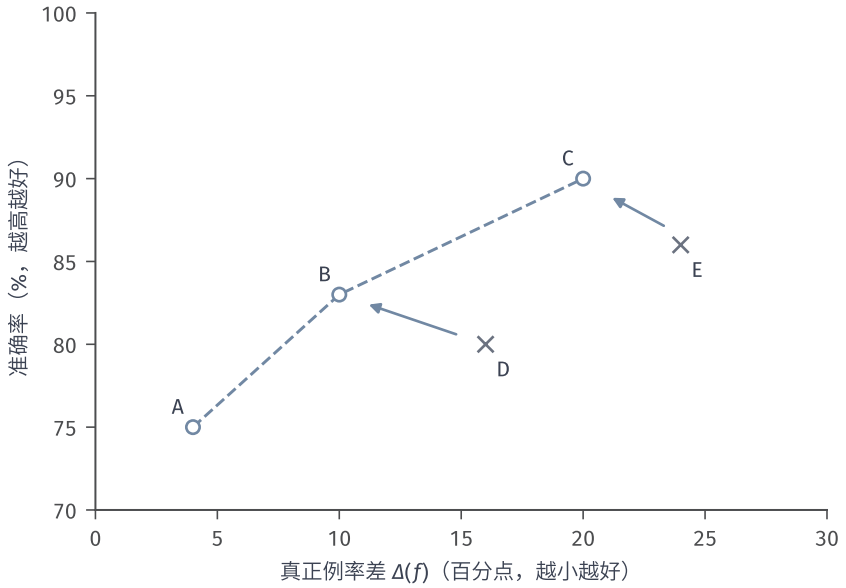


图 13.5 构造两组各 100 人、各 50 人合格，由五套混淆计数得到“真正例率绝对差、准确率”。A、B、C 为（4 个百分点，75%）、（10 个百分点，83%）、（20 个百分点，90%），D、E 为（16 个百分点，80%）、（24 个百分点，86%）。B 支配 D、C 支配 E，空心圆是当前候选中的不可支配者。虚线引导阅读，未证明中间点可实现。

$\hat{R}_a$ 为组内损失。训练梯度按权重累积，之后独立检查公平量。小组不再仅因少而被忽略，但错误率未被强制相同，标签也未被修复；半半目标仍需任务批准。

**表示中的信息依赖** 多个任务复用特征时，可以在表示中限制群体信息。Zemel 等的 Learning Fair Representations 将样本软分配到原型，同时比较重构、预测和组间原型分配。它约束变换后的编码，不只是删字段[10]。

记原型概率 $q_k(\boldsymbol{x})$，组均值 $\bar{q}_{k,a}$，可用 $\sum_k |\bar{q}_{k,u} - \bar{q}_{k,v}|$ 惩罚。若先按 $q_k$ 抽原型，再只依原型决策，各组平均分配完全相同便由全概率得相同机会。经验近似相同或把整个软向量交任意预测器，没有这一无条件继承；下游用法改变需重新检验。

训练共同调整原型、分配和预测器。重构防止丢全部信息，预测保留任务区分，分配惩罚减少指定差别，权重控制取舍。独立资料还要分别测效用、群体可预测性和最终决策，仅惩罚下降未证明下游公平。

也可以训练一个辅助预测器寻找残留信息。**对抗去偏**（adversarial debiasing）使任务模型与根据表示或输出猜属性的对手竞争。Zhang 等将其用于减少特定差距，效果仍取决于对手所见与能力[11]。

[10] R. Zemel, Y. Wu, K. Swersky, T. Pitassi, C. Dwork, *Learning Fair Representations* In Proceedings of the 30th International Conference on Machine Learning, 2013, pp. 325–333

[11] B. H. Zhang, B. Lemoine, M. Mitchell, *Mitigating Unwanted Biases with Adversarial Learning* In arXiv preprint arXiv:1801.07593, 2018

令任务输出 $h_\theta$、属性预测器 $d_\phi$，经验任务和群体损失为 $L_{\text{task}}, L_{\text{group}}$，取舍系数 $\lambda \geq 0$。竞争目标可写为

$$\min_{\theta} \max_{\phi} \{L_{\text{task}}(\theta) - \lambda L_{\text{group}}(\theta, \phi)\}.$$

固定任务模型时训练对手降低群体损失，固定对手时降低任务损失、提高群体损失，部署通常只留任务模型。另训独立攻击者检查是否绕过原对手。只看输出时，这减少的是给定函数类、样本和优化精度可检测依赖；均等化赔率需控制标签内剩余依赖，可分标签训练。对手未胜基准没有证明独立或排除更强者；竞争不稳、任务与属性信息重叠仍会产生取舍。

**公平约束下的分类学习** 表示约束间接改变公平，已知准则也可直接转为条件矩，即指定群体和标签中预测指示或损失的平均。例如真正例率差拆为 $\hat{t}_u - \hat{t}_v \leq \eta$ 及逆向一项，各 $\hat{t}_a$ 由组正例的指示均值得到。Agarwal 等把外层公平约束归约为**成本敏感分类**（cost-sensitive classification），调整每样本每种错误代价，再调用既有学习器，保留其表示形式[12]。

[12] A. Agarwal, A. Beygelzimer, M. Dudík, J. Langford, H. Wallach, *A Reductions Approach to Fair Classification* In Proceedings of the 35th International Conference on Machine Learning, 2018, pp. 60–69

记候选 $\mathcal{F}$、有限约束 $\mathcal{J}$，带方向的经验差异 $\hat{g}_j(f)$ 与容限 $\eta_j$，超限量为 $\hat{g}_j(f) - \eta_j$，约束对随机分类器混合线性。部署按支持于 $\mathcal{F}$ 的分布 $Q$ 抽规则，拉格朗日形式为

$$\min_{Q:\ \text{supp}(Q) \subseteq \mathcal{F}} \sup_{\lambda \in \mathbb{R}_+^{|\mathcal{J}|}} \left\{ \mathbb{E}_{f \sim Q}[\hat{R}_{\text{tr}}(f)] + \sum_{j \in \mathcal{J}} \lambda_j \left( \mathbb{E}_{f \sim Q}[\hat{g}_j(f)] - \eta_j \right) \right\}. \tag{13.7}$$

乘子可取任意非负值，因此只要某项平均差异超过容限，就能不断增大该项乘子，使上确界变为无穷大；满足全部约束的混合才保留有限的风险值。训练时，乘子为违反准则的错误增加成本，学习器响应这些成本。多轮分类器的混合还可产生单一确定规则无法实现的中间率。实际算法另限制乘子域和停止精度，公式只说明约束作用。

若某组真正例率低于要求，就增加该组正例被误拒的代价；若调整后假正例率超过上限，则提高该组负例被误收的代价，抑制过多的错误录取。反馈可追踪到哪组哪种错误，未将“惩罚越大”当作充分改进。

从初始乘子训练、计算违规、增大违规项乘子并重复，保存候选及最终混合权重，不能只选准确率最高的一轮。此法直接反馈准则，对抗去偏反馈可预测属性；优化形式相似没有使两者同义。

归约依赖候选族、成本学习器能力和求解误差，经验达标仍需独立总体审计及容差。属性可仅在训练构造约束，部署读取什么由模型族决定，与使用时必须识组的后处理不同。

交叉组太多时，可交替学习与审计：搜索当前最高加权违规组，将第 13.2.1节审计所用的相同参照、质量和差异转为下一轮约束。改一交叠组可能影响其他组，停止要检查约定全族并独立验证，不能只看最后发现的组。

个体要求可按认可距离惩罚决策差超限，再用未优化个体对检验；反事实要求可按认可因果结构构造不受禁路径的依据或约束世界间一致。测验 $x - \gamma a$ 仅在结构成立时有效，优化一致没有修复不可靠机制。总体比例均等不能代替这两项。

### 13.3.3 决策规则与服务流程的调整

无法重新训练模型时，仍可修改两种对象：分数失准时调整分数；机会分配或错误率违反要求时，调整把分数转成行动的规则。二者会互相影响，各自达标仍需分别检验。

针对式 (13.3)，可按组区间平均残差修分数，再检查交叠组；正式方法还控制步长、搜索和泛化。新分数要重新校准，下游固定阈值的获选名单也可能改变，所以分配量须重算。

保留原分数而改规则，可选择组别阈值，每组形成 ROC 中的假正例、真正例点。以预设概率为每人独立于分数、其他特征和标签选两个阈值，期望率才是点的凸组合。Hardt 等据可达区域选择满足均等化赔率的共同错误点。

> **示例 13.2　随机化如何补出共同错误率**　构造独立验证结果：第一组两阈值的 $(f, t)$ 为 $(0.1, 0.5)$、$(0.3, 0.9)$，第二组一阈值为 $(0.2, 0.7)$。第一组每人按预设各半概率独立选阈值，且独立于分数、其他特征与标签，平均点便为 $(0.2, 0.7)$。两组在这批验证记录上的期望错误率相同，一次实际随机选择得到的样本率仍可能波动。部署时还要检查目标分布是否支持这些率，并估计相应误差。

共同可达点的真正例率可能低于下限，假正例率可能超过上限，效用也可能低于要求。错误率均等有时是通过降低原本较好组的获选水平实现的。后处理不能增加原排序信息，也可能给相近个体因组别而不同机会，未保证个体公平。其收益是固定分数下可算取舍，限制是表示和排序固定。采用须符合属性用途、资源与实际后果。

服务干预还包括复核、补材料、纠错以及语言和提交渠道支持，需记录标准与时延。人工不是公平证明，要分别检查各组转交、等待和最终结果；大量转人工却迟迟不服务，自动错误减少也未证明改善。

生成建议可在服务规则中限定证据、请求信息和复核表达，再用受控身份任务验收。训练也可用核实对照及反馈，“用了去偏数据”仍不是内容达标证据。

### 13.3.4 干预效果与持续调整

各位置干预都返回同一要求验收。即时比较评估当下收益，长期跟踪检查数据和状态改变后是否仍满足要求，结合结果决定保留、调整或撤回。

**即时效果与负担转移** 即时对照固定任务、群体、标签和准则，在未用于选择的同一批资料比较规则，保存效用、组指标、目标及变化误差。若过程改变人群和标签，还需后续识别。例如，两组真正例率的差距从 0.2 降为零，既可能是原本较低的一组从 0.6 升到 0.8，也可能是原本较高的一组从 0.8 降到 0.6。只有同时记录修改前后的真正例率、假正例率和获选名额，才能判断合格者机会是否改善；还需检查负担有没有转移给其他人或其他环节。

模型暂不作出自动决定而将请求转交人工时，需按组报告第 11.2节的处理比例及接受风险。大量转交某组的请求，可能降低自动处理部分的错误率，却未证明服务更公平，等待、人工成本和结果仍要计入。服务覆盖指获得处理比例，与集合覆盖真实标签不同。

主要标准先由要求确定，其他指标揭示代价；不断挑最有利指标会只显示局部收益。样本不足时报告不确定，差异不显著未证明不公平消失。

**选择性标签与后续结果** 长期干预改变比较条件本身。曝光增加会产生更多点击证据，培训又改变未来能力和资格。静态通过之后，仍要追踪机会、能力与负担的动态。

如果给定特征与群体属性后，获选与培训后的潜在结果没有额外关联，且各类人都有正的获选概率，就可以尝试按选择概率加权，修正结果只对获选者可见所造成的偏差。这些条件分别称为条件可交换性与正概率覆盖，随后将写出它们的数学形式。某类从未获选时，没有正概率就无法恢复其结果，需要另取得证据并核查取得条件。

Lakkaraju 等利用不同决策者的选择差异研究选择性标签评价，说明验证标签可能由待评价决策产生。决策者差异仍需比较假设，不能直接认作随机实验[13]。

为避免把后续收益混入资格，记培训结果 $z$，获得机会 $r = 1$，潜在结果 $z(1)$，选择概率 $e(\boldsymbol{x}, a) = \mathbb{P}(r = 1 \mid \boldsymbol{x}, a)$。假设所考察群体具有正概率，

[13] H. Lakkaraju, J. Kleinberg, J. Leskovec, J. Ludwig, S. Mullainathan, *The Selective Labels Problem: Evaluating Algorithmic Predictions in the Presence of Unobservables* In Proceedings of the 23rd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 2017, pp. 275–284

$z(1)$ 在该群体内可积；给定特征和属性时 $r$ 独立于 $z(1)$，$e > 0$ 在该群体的特征分布下几乎处处成立，且获选者 $z = z(1)$。逆概率加权于是给出

$$\mathbb{E}\left[\frac{rz}{e(\boldsymbol{x}, a)} \mid a\right] = \mathbb{E}[z(1) \mid a]. \tag{13.8}$$

$r = 0$ 时乘积定义零，无需观察其 $z$。先条件化再用独立性消去选择概率，最后组内平均便得右侧（可参考第一卷“因果响应”章的“响应目标的点识别”小节中的逆概率表示）。审核者使用未记录的信息，可能破坏这一条件独立性，小概率放大方差，做加权之前需检查这些条件。

Liu 等的 Delayed Impact of Fair Machine Learning 进一步用决策后状态模型分析，静态约束在其假设下可帮助也可损害保护组。方向由新增获选者、状态变化机制和原分布共同决定[14]。

构造获得机会后成功使状态增加 1、失败使状态减少 2 的情形，成功概率为 $p$，期望净变为 $p - 2(1 - p) = 3p - 2$。$p = 0.5$ 时每个新增参与者平均减 0.5，所以机会增加未必改善状态。这是机制例而非培训数据；在其他人的状态保持不变的这个模型中，新增正决策的条件净收益为正，才会提升群体的平均状态，每人改善还需更强条件。费用补助、课程改变或失败代价降低，也可改变结果。

新差异出现后，回到数据、测量和干预副作用定位原因，再用声明标准与新证据调整；继续增加当前差距惩罚未必改对机制。

[14] L. T. Liu, S. Dean, E. Rolf, M. Simchowitz, M. Hardt, *Delayed Impact of Fair Machine Learning* In Proceedings of the 35th International Conference on Machine Learning, 2018, pp. 3150–3158

## 13.4 本章小结

培训分配要先给差异的规范依据，再分别检查机会与负担、预测错误与分数含义、个体待遇、影响路径和社会表征。统计、距离、因果与内容证据各有条件，准则又可能冲突，结论应限定任务、人群及证据，区分达标、违反和不足。

没有满足要求时，应按形成原因补充遗漏人群的数据、修正测量与标签、调整训练或改变服务流程。这些措施可以组合，却不能互相替代。验收时保存各组原有水平、实际收益及后续变化，避免通过降低服务水平或转移负担得到表面的比例一致。某指标改善仍可能没有实现本意，下一章将扩到一般目标与行为边界；采集审计所需属性也受第 16章的信息保护限制。

**延伸阅读** 机会均等后处理与个体公平分别保护标签条件率和任务相似性，对照 Hardt 等与 Dwork 等可辨认各自对象、冲突及不互推关系[15,16]。

反事实公平与延迟影响分别依赖因果机制和后续状态模型，Kusner 等与 Liu 等的分析可帮助区分经验率、允许路径与长期后果；结论都需保留建模假设[17,18]。

[15] M. Hardt, E. Price, N. Srebro, *Equality of Opportunity in Supervised Learning* In arXiv preprint arXiv:1610.02413, 2016

[16] C. Dwork, M. Hardt, T. Pitassi, O. Reingold, R. Zemel, *Fairness Through Awareness* In Proceedings of the 3rd Innovations in Theoretical Computer Science Conference, 2012

[17] M. J. Kusner, J. R. Loftus, C. Russell, R. Silva, *Counterfactual Fairness* In Advances in Neural Information Processing Systems, 2017

[18] L. T. Liu, S. Dean, E. Rolf, M. Simchowitz, M. Hardt, *Delayed Impact of Fair Machine Learning* In Proceedings of the 35th International Conference on Machine Learning, 2018, pp. 3150–3158

第 14 章

# 目标对齐与行为约束

整理邮件的助手需要提高查找效率，同时保留重要内容。若训练只奖励处理速度，它可能省略核查；若只奖励即时好评，它可能用缺少依据的回答取悦用户。这两种偏离都不需要攻击者介入：当训练信号没有完整表达任务要求时，成功优化信号也可能损害实际目标。

上一章用可检验的分配目标和干预规则表达公平要求。邮件任务同样需要把希望达到的结果、训练中使用的反馈以及执行中必须满足的边界分别说明。只有明确这三个对象，才能判断系统究竟完成了任务，还是仅获得了较高评分。

在第 10章的三层架构中，目标对齐和行为约束属于系统属性或规范要求层，规定系统应追求的结果与可以采取的行为。可靠性、鲁棒性和公平性能够提供相关证据；训练、推理与执行机制则把要求落实到行为。要求的正当性及其实现效果因此需要不同层面的判断。

本章先定义目标与约束，再讨论如何从输出、操作和状态中取得评价与监督证据。随后检查这些证据能否支持新情境、长交互与版本更新中的行为保持，最后介绍改变行为和限制后果的干预。各节围绕同一个邮件任务展开，以便比较不同机制实际解决的问题。

## 14.1 目标对齐与行为约束的基本概念

### 14.1.1 目标对齐与行为约束的含义

整理邮件可以以减少查找负担、保留重要信息为目标，而收件箱变空只是其中一个可测结果。**目标对齐**（alignment）要求模型学得的行为符合给定的实际目标。本章的技术分析以任务授权和适用规范已经确定为前提，研究目标如何通过代理信号表达、如何约束行为，以及怎样验证结果。目标由谁提出、多个主体的要求怎样取得正当性，仍由外部治理决定；系统应记录决定的来源，在冲突未解决时请求澄清、拒绝执行或升级处理。

**行为约束**（behavioral constraint）规定可接受行动必须满足的条件。邮件助手可以只获得本次任务指定邮件的操作权限，并被要求保留重要内

容、在信息不足时先核查。目标用于判断结果是否值得实现，约束用于判断实现路径是否允许。未经授权转发即使有助于整理也会违反约束；完全不行动虽然避免了越权，却没有达到整理目标。

对齐和约束的检验需要落到观察对象上：回答是否有事实依据，操作对象是否经过授权，任务结束后的状态是否满足要求。模型声称理解目标只能作为输出记录。已知偏离可以通过明确规则识别，复杂目标则需要结合任务结果、人工判断与其他证据，说明判定能够覆盖哪些行为。

图 14.1中的两个方案都清空收件箱，因而按这一指标都可得高分。核查重要邮件能否检索后，删除与归档才会得到不同评价。图中的差别说明评价对象应由保留要求确定，不能由最容易测量的界面状态替代。

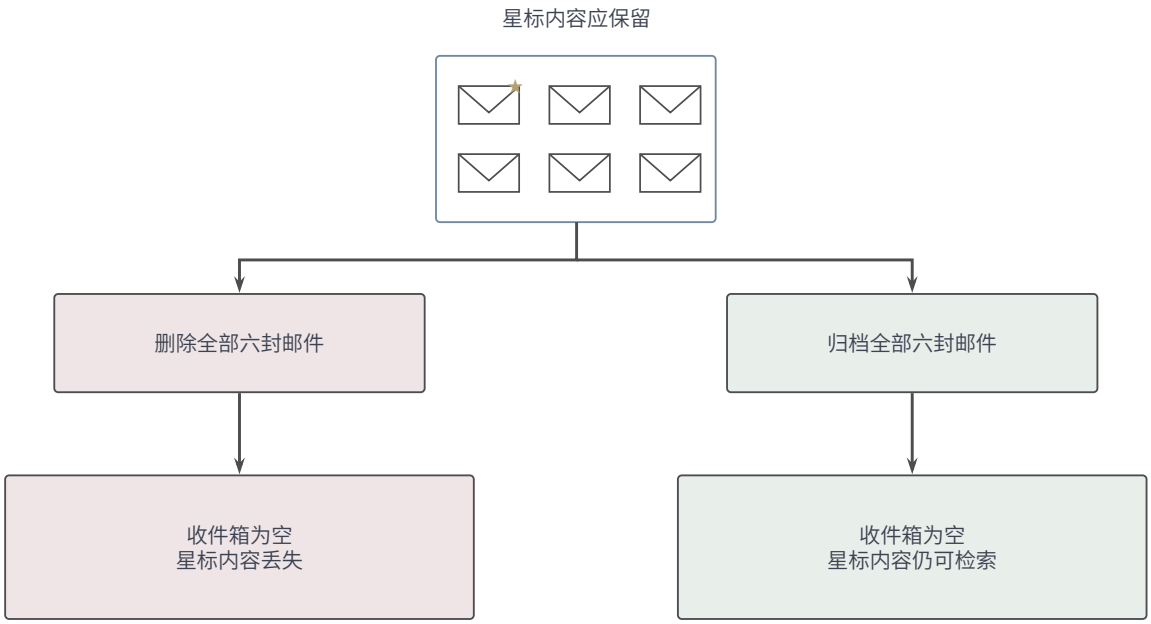


图 14.1 删除与归档都使收件箱变空，但只归档保留可检索的重要邮件。左侧删除包括星标内容，右侧将内容移入归档；星标标明保留要求，空收件箱对应被评分的界面状态。核查后果才能区分两种表面完成。

### 14.1.2 行为偏离的表现与原因

仅以清空收件箱打分，无法区分删除与归档的后果。为分析实际目标与训练信号的差别，设任务轨迹为 $\tau$，在授权、规范与后果聚合方式固定后，以 $U(\tau) \in \mathbb{R}$ 评价实际后果，较大值表示更符合给定目标。这个标量是分析模型中的对象；其数值未必可观测，也不存在适用于所有主体的唯一取值。不可补偿的约束仍须另行表达。固定环境模型，从历史 $h$ 实施当前动作 $a$，再按后续策略 $\pi$ 生成轨迹。若 $U$ 在该轨迹规律下可积，动作的期望效用为

$$Q_U^{\pi}(h, a) = \mathbb{E}_{h,a}^{\pi}[U(\tau)]。$$

$\mathbb{E}^{\pi}_{h,a}$ 表示按环境转移与策略从给定历史、动作继续生成的轨迹规律取平均，未要求历史行为曾以正概率选取这个动作。静态候选排序也可以把后续过程纳入这个期望。实际系统通常只能取得评分、点击、比较标签或完成标记，再由这些观察构造奖励 $r(h,a)$。奖励与效用在原数据中相关，只支持相应分布上的代理关系；加强优化后是否仍一致，需要继续检验。

**奖励投机**（reward hacking）描述获得高奖励却偏离奖励所代表目标的行为。以文件数量减少衡量整理效果，会把删除应保留文件也计为进步。纠正这种问题需要检查目标如何被表达、评价器遗漏了什么以及环境提供了哪些漏洞；进一步提高同一个奖励的优化效率仍会保留这些缺陷。

目标中的个体偏好可以随主体和情境改变，例如回答的长度与细节程度。另一些要求涉及共同适用的边界，例如处理他人信息是否有授权。收集反馈时应先确定哪些差异可以个性化、哪些条件需要所有候选满足，避免把某位用户的偏好误当成放宽权限的依据。

以下例子固定同一任务：整理旧邮件，保留重要标记的内容，并禁止向未授权对象转发；在满足这些条件以后，整理方式可以依据用户偏好选择。对一封既旧又重要的邮件，方案 $A$ 为归档并建立索引，$B$ 为保留在收件箱并加标签，$C$ 为删除。前两者可比较效率与风格，第三者因违反保留要求而应被排除。

反馈应记录比较依据。摘要的整体分数可能同时受到遗漏信息、语气、长度和隐私处理的影响，单个分数无法说明哪一方面出了问题。对事实完整性与硬约束分别提供证据，再在可行候选中评价表达偏好，才能把修改方向传递给后续训练。

评价误差还会受到选择过程影响。固定 $U$、环境模型与后续策略后，可写 $r(h,a) = Q^{\pi}_{U}(h,a) + e(h,a)$，其中 $e$ 度量相对于同一条件期望的代理误差。环境结果的随机波动仍存在于 $U(\tau)$ 与 $Q^{\pi}_{U}$ 之间；目标规范、后果聚合及环境模型的错设也不在这一误差项中。设原行为诱导历史与动作联合分布 $d_0$，即使 $\mathbb{E}_{(h,a)\sim d_0}[e(h,a)] = 0$，择优后的分布 $d_{\mathrm{sel}}$ 也可能满足 $\mathbb{E}_{(h,a)\sim d_{\mathrm{sel}}}[e(h,a)] > 0$。择优偏爱高分候选，而高分可以来自真实效用或评价高估；原分布上的无偏性因此不能直接迁移到所选候选。

**示例 14.1　奖励误差被优化放大**　设三个邮件整理方案的真实效用为 $8, 7, 2$，代理评分为 $8, 7, 9$。只在前两个候选中选择时，评分给出的次序正确；搜索范围扩大到第三个候选后，最大评分对应的真实效用降为 2。第三个候选可以通过删除难分类邮件使界面整洁，却损害了重要信息。这个例子把偏离定位在评价器对新候选的高估：搜索确实找到了最大代理分数。

图 14.2用人为构造的函数进一步表现这一关系：优化强度增加时代理分数单调提高，实际目标则先升后降。两条曲线用于说明可能的形状，不提供真实系统中转折点或损害程度的估计。

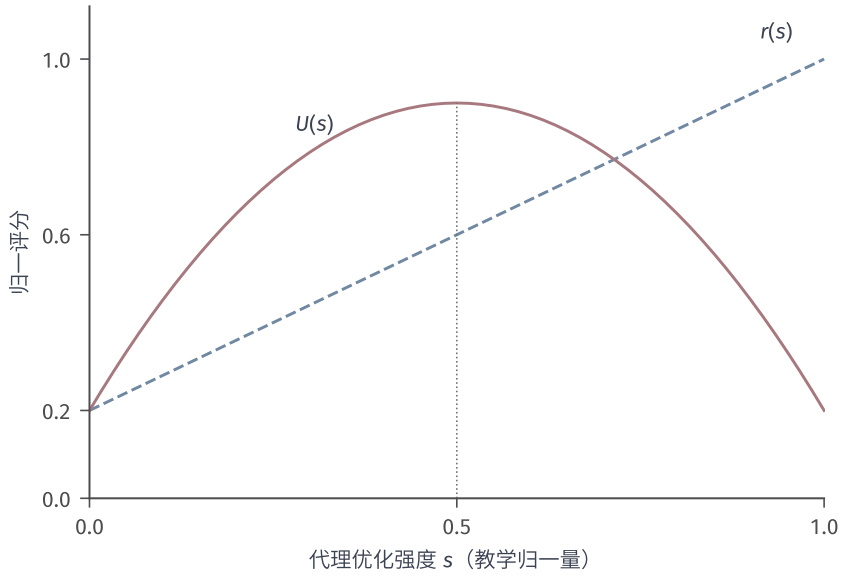


图 14.2 代理过度优化的教学曲线。人为设 $s \in [0,1]$ 为归一优化强度，代理 $r(s) = 0.2 + 0.8s$ 单调增加，目标 $U(s) = 0.2 + 2.8s(1 - s)$ 在 $s = 0.5$ 达到最大后下降。实线与虚线分别表示目标和代理；数值只用于构造关系，不是奖励模型实验或人类价值测量。

Gao 等先用固定的较强奖励模型产生比较标签，再训练代理奖励模型，通过强化学习和多样本择优改变优化强度。在其控制实验中，代理分数持续提高以后，较强模型给出的参照分数可能下降。这里的参照仍是模型评价，不能据此把参照分数等同于真实人类价值；实验支持的是所研究设置下代理过度优化的现象[1]。

判断优化后的改进，需要引入没有被同一优化过程使用的证据。邮件任务可以核对保留清单与实际操作，而非让原奖励模型再次评分。降低优化强度能够限制向高误差区域的搜索，补充事实和约束反馈则可能修正代理本身；两种处理针对不同环节，其效果应分别验证。

行为偏离也会以迎合、表面合规和过度拒绝出现。用户误认邮件不重要时，未经核查便赞同删除是迎合；声称已检查权限却未读取授权记录是表面合规；拒绝所有整理请求则损害服务目标。验收需要同时观察违规与合法任务完成，才能区别这些情况。

[1] L. Gao, J. Schulman, J. Hilton, *Scaling Laws for Reward Model Overoptimization* In arXiv preprint arXiv:2210.10760, 2022

### 14.1.3 软目标与行为边界

邮件整理既希望提高效率，也需要限制误删等风险成本，因而只最大化效率奖励还不足以表达全部要求。设策略 $\pi$ 按历史 $h_t$ 选择动作 $a_t$，$r_t$ 为奖励，$c_t \ge 0$ 为风险成本，$T$ 为时域，$b$ 为预算。一种常见表述为

$$\max_{\pi} \ \mathbb{E}_{\pi} \sum_{t=0}^{T-1} r_t, \qquad \mathbb{E}_{\pi} \sum_{t=0}^{T-1} c_t \le b, \tag{14.1}$$

它限制平均累计成本，因而不能保证每条轨迹都满足要求（可参考第一卷“策略的价值与优化”章的“轨迹收益与策略价值”小节和同章的“策略的轨迹价值与风险”一节）。明确禁止的动作需要在动作集合或执行权限中排除；失败概率要求则需先定义失败事件，再建立相应概率约束。

将成本作为奖励惩罚项便于优化，但惩罚强度决定了算法愿意怎样交换收益与成本。加入惩罚后仍要直接检验原约束。只有证明或测得所规定条件满足，才能把训练设置转为行为约束的证据。

例如，两个方案的收益与成本分别为 $(10, 1)$ 和 $(5, 0)$。按 $r - \lambda c$ 优化且取 $\lambda = 2$ 时，得分为 8 和 5，策略仍选择有成本的方案。若该成本代表不可补偿的违规，奖励权衡便没有忠实表达原要求；改变系数的效果也需另行核查。

长期任务还需要定义成本单位。累计违规次数、至少一次违规的指示量和最终经济损失是不同对象。式 (14.1)中的零成本步骤不会减少已经累计的成本，但对轨迹取期望仍允许不同轨迹之间平均；若改用每步平均成本，增加零成本步骤还可能稀释比例。约束的聚合方式应由任务容限决定。第 10.2节提出的要求，在这里需要落实到轨迹、动作和受影响对象。

## 14.2 行为的评估与监督

邮件计划 $C$ 违反保留要求时，系统既要判出问题，也要说明这一判断怎样进入后续训练或执行。行为评估根据任务要求判断输出与行动是否合适；行为监督则持续使用这些判断，形成反馈或告警。离线评价、训练反馈与在线监测可以共享判据，但评价所得证据不会自动更新参数，告警也不会自动停止行动。各环节需要明确接收判断后的实际操作。第 14.4节将说明怎样通过训练、推理与执行机制实际改变行为。

建立监督体系时，先确定需要判断的性质，再选择相应记录和评价者，最后验证判断的准确性、及时性与使用负担。整体好评分数会合并目标达成、规则违反与风格偏好，因此应从任务要求中拆出可以独立检查的对象。

### 14.2.1 行为评估与监督的维度

同一条邮件整理轨迹可以同时接受多方面评价：

- 目标达成与结果质量：检查重要内容是否保留，检索是否可用，摘要是否准确完整。
- 约束遵守：核查操作对象、收件人和授权范围，并记录违反的性质与严重程度。
- 过程与证据使用：确认必要标记、工具状态及授权记录是否实际读取并用于决定。
- 不确定情况下的处置：检查信息缺失时是否澄清、停止或贸然执行，同时统计对合法请求的错误拒绝。

表达风格可在满足关键条件的候选之间比较。对于不可补偿的违规，应另设判据，使高任务收益不能将其抵消。改变情境后，仍需沿这些维度检查要求是否保持；有关条件见第 14.3节。

上述维度描述要判断什么，评价方法描述怎样取得证据。越权可以通过权限表、人工复核或模型判断检查，人工反馈也可以同时评价事实与风格。结果与过程则规定标签落在什么粒度上。将性质、来源和粒度分开，便于组合方法而不重复计算同一证据。

### 14.2.2 行为评价信号的获取

行为评价既可以核对事实与状态，也可以比较候选的相对优劣。构造信号时应同时说明判断者与依据，以及标签附在最终结果还是中间步骤。接下来从可核查证据进入偏好比较，再说明原则评价和过程标签如何扩大反馈范围。

**事实与规则支持的直接核验**　当任务具有明确状态或真值时，应优先核对这些对象。保留要求对应操作前后的邮件记录与索引，授权要求对应动作对象和收件人，摘要事实对应原文。规则检查器能给出所编码条件是否成立，但仍受状态可信度、检查规则覆盖和工具实现限制。

**人工比较与偏好评价**　对于难以给出绝对分数却能比较候选的任务，可以收集偏好数据。先固定任务、候选对与比较者的抽样总体，并单独记录弃权和无法判断的情况。设上下文为 $\boldsymbol{x}$，优选回答为 $y^{+}$，另一回答为 $y^{-}$，奖励模型为 $r_{\boldsymbol{\phi}}$，可用

$$\mathbb{P}(y^{+} \succ y^{-} \mid \boldsymbol{x}) = \sigma\big(r_{\boldsymbol{\phi}}(\boldsymbol{x}, y^{+}) - r_{\boldsymbol{\phi}}(\boldsymbol{x}, y^{-})\big)\,,$$

表示比较概率，其中 $\sigma(u) = 1/(1 + e^{-u})$。概率对应既定比较者总体的抽样与判断随机性；对已观察比较最小化负对数似然，即可拟合奖励差。这一参数化并未解释偏好形成的因果机制，结果仍依赖比较者、呈现方式和数据分布。

这里观察的是比较结果，奖励函数是用来解释这些结果的模型。若不同奖励函数给出相同比较概率，数据便不能区分它们；在未覆盖的候选上也不能仅凭拟合结果确定排序（可参考第一卷“数学基础与后续研究”章的“训练样本生成规律下的统计目标可识别性”小节）。

每条偏好记录应包含同一上下文、两个候选和比较结果。当前策略可生成 $A$、$B$，随机交换展示位置，再保存比较者身份、群体和无法判断的情况。位置随机化有助于控制位置偏差，仍需检查任务、候选与比较者的代表性。主动选择难判断的样本适用于训练，最终验收应另取独立样本。

设教学数据中同一对可行方案得到四次判断，三次选 $A$、一次选 $B$。令 $p$ 为选择 $A$ 的模型概率，平均负对数似然为 $-\frac{3}{4}\log p - \frac{1}{4}\log(1-p)$，在 $p = 3/4$ 时最小。相应奖励差为 $\log 3$。这只拟合 $A$ 和 $B$ 的比较；删除重要邮件的 $C$ 仍应由保留约束排除。

这一参数化称为 Bradley–Terry 偏好模型。给同一上下文的所有奖励加上常数不会改变比较概率，所以成对数据不能识别绝对零点；固定逻辑函数的尺度后，奖励差才有相应单位。单一标量排序也难以表示循环偏好或群体间稳定分歧，需要保留这些结构而非用平均标签掩盖。

例中的 3/4 表示比较者选择 $A$ 的概率，不能解释为 $A$ 真实、无害或满足全部约束的概率。将奖励分数用作安全置信度之前，必须明确其预测事件与校准依据；第 11.2节讨论的概率校准也不能从偏好拟合自动获得。

**原则指导的模型评价** 人工比较的成本限制了反馈规模。宪法式人工智能（Constitutional AI）以人编写的原则指导模型批评、修订与比较回答：先用修订结果进行监督微调，再用模型比较训练偏好模型并优化策略，这类模型反馈也称 RLAIF。原则的选择仍来自人，其内容不因称为“宪法”便自动取得法律或普遍规范效力[2]。

评价模型需要同时看到任务、候选、相关事实与适用原则，才能把原则转换为局部标签。若候选 $C$ 提议删除旧邮件，而工具记录标明它重要，评价应指出保留要求冲突并修订为归档方案。产生批评、修订或比较标签的是模型，后续仍分别进入示范或偏好学习环节。

原则评价扩大的是具体判断的生产规模。原则之间发生冲突时，评价器还需要明确优先关系，例如积极完成请求与禁止未授权披露信息之间的关系。只生成一段符合原则措辞的批评，可能没有改变事实判断或操作；验证必须检查修订后的行为。

[2] Y. Bai, S. Kadavath, S. Kundu, A. Askell, J. Kernion, A. Jones, A. Chen, A. Goldie, A. Mirhoseini, C. McKinnon, C. Chen, C. Olsson, C. Olah, D. Hernandez, D. Drain, D. Ganguli, D. Li, E. Tran-Johnson, E. Perez, J. Kerr, J. Mueller, J. Ladish, J. Landau, K. Ndousse, K. Lukosuite, L. Lovitt, M. Sellitto, N. Elhage, N. Schiefer, N. Mercado, N. DasSarma, R. Lasenby, R. Larson, S. Ringer, S. Johnston, S. Kravec, S. El Showk, S. Fort, T. Lanham, T. Telleen-Lawton, T. Conerly, T. Henighan, T. Hume, S. R. Bowman, Z. Hatfield-Dodds, B. Mann, D. Amodei, N. Joseph, S. McCandlish, T. Brown, J. Kaplan, *Constitutional AI: Harmlessness from AI Feedback* In arXiv preprint arXiv:2212.08073, 2022

反馈来源改变后，应针对新的误差来源验收。人工比较需要分析群体与分歧，模型比较还需检查评价者和生成者是否共享盲点。抽样复核应覆盖原则在具体事实中的落实、正常请求的过度拒绝，以及不同评价者的系统差异。

**结果评价与过程评价** 长任务只有最终标签时，失败原因很难定位。在中间操作、证据检查或计划选择上增加反馈，可以发现哪些步骤需要改进。不过，局部合理的步骤仍可能组成失败轨迹，过程评价需要与最终结果对照。

**结果监督**（outcome supervision）对最终产物提供评价，**过程监督**（process supervision）把标签附在中间步骤。最终答案错误的标签无法直接指出计算从何处出错，偶然正确的答案也可能掩盖错误推导。过程标签提高定位粒度，同时要求标注者理解局部推理，并承担更多标注工作。

Lightman 等在数学解题设置中训练过程奖励模型，利用人对推导步骤的标签评价多个候选解法。其结果显示过程监督优于所比较的结果监督基线，结论限于相应数学任务、标注和生成设置。步骤文本得到正标签并不证明内部推理忠实，也不能直接担保工具代理的行动安全[3]。

[3] H. Lightman, V. Kosaraju, Y. Burda, H. Edwards, B. Baker, T. Lee, J. Leike, J. Schulman, I. Sutskever, K. Cobbe, *Let's Verify Step by Step* In arXiv preprint arXiv:2305.20050, 2023

在邮件任务中，最终状态能够检验重要邮件是否保留；过程记录还可以定位删除前是否读取标记、转发前是否核查收件人。前者检查后果，后者检查决定的输入。日志中一句“已核查”并不证明核查发生，应以真实读取和工具调用记录作证。

过程训练样本需要保存历史、待评步骤和局部标签。对“读取标记—归档—检查可检索性”的路径，可给实际读取并正确使用标记的步骤正标签，给没有读取却声称已确认的步骤负标签。比较过程与结果监督时，应固定候选和评价预算，并使用独立的任务结果检验其效果。

过程分数的聚合取决于分数含义。若 $q_t$ 是前序步骤均正确条件下本步正确的概率，链式法则给出整段正确概率 $\prod_t q_t$，无需独立性。任意步骤评分则没有这一乘法解释。采用最小值、平均或加权和时，应说明希望强调的错误类型，并用任务结果验证聚合规则。

### 14.2.3 运行行为的观测与监测

只保存最终摘要时，邮件助手是否读取重要标记往往无法判断。运行监督应先选择可见信息。最终结果与目标直接相关，但可能在损害之后才出现；动作记录便于检查权限与流程，中间推理文本则可能提供预测线索。若利用推理文本解释行为，还需另行检验文本对内部过程的忠实性；预测告警效果与解释忠实性是不同要求。第 15.4节将进一步说明解释的保真度及其检验。

设监控器读取历史 $h_t$ 的可见部分 $v(h_t)$ 并输出 $m(v(h_t))$。缺少关键工具参数的日志不能支持确定的越权判断，即使最终摘要看似完整。扩大记录范围可能提高检出，也增加采集、计算、隐私和保存成本；应将这些代价纳入监控设计。

监控训练首先需要把可见记录与偏离事件对应。可以直接从动作名称、重要标记和授权表构造规则标记，识别拟议删除或未授权收件人。需要语义判断的情况可用已核验标签训练分类器。规则命中和分类分数都只形成判断或告警，实际阻断仍依赖后续执行机制。

仅记录“已安全归档”无法检验删除方案 $C$ 是否被执行。删除前的重要标记与动作参数使事前冲突检查成为可能，工具返回则用于核查事后状态。要在损害前发挥作用，还须保证解析正确、记录及时且监控有相应权限。比较不同日志方案时，应同时测量漏报、误报和时间代价。

可见信息齐全也可能超出评价者的判断能力。因此，补充日志后还要检查监督者能否理解事实与约束；任务分解、证据查询和辅助工具针对的是这一判断能力问题。

### 14.2.4 复杂任务中的监督能力

邮件助手能够整理很长的报告，而评价者未必能一次核清每项事实与授权。当执行模型的任务能力超过评价者时，完全模仿评价者可能丢失已有能力。**可扩展监督**（scalable oversight）研究利用分解、工具与辅助判断扩大监督范围的方法。监督过程可以借助这些资源，最终准确性仍需由独立证据检验。

**弱到强泛化**（weak-to-strong generalization）把能力差距转化为可测训练问题：较弱模型生成标签，具有较强预训练能力的模型据此学习。Burns 等在自然语言、国际象棋和奖励建模任务中比较这一过程，并在部分设置中利用置信度等辅助目标改善学生表现。实验支持相应任务上的能力恢复，未建立任意任务的监督保证[4]。

这些实验检验弱标签能否引出强学生的既有能力，尚未直接检验运行监控。强学生具有预训练知识，因而不等于从弱标签中获得全部信息；预训练也不能保证它纠正每个错误标签。将其用于行为监督，需要对具体违规事件另测检出与误报。

衡量能力恢复时，应固定同一测试分布、聚合口径及数值越大越好的指标。记弱监督者、弱标签训练的强学生、可信标签训练的强参照得分为 $s_{\mathrm{w}}$、$s_{\mathrm{ws}}$、$s_{\mathrm{s}}$，并要求 $s_{\mathrm{s}} > s_{\mathrm{w}}$。恢复比例可写为

$$g = \frac{s_{\mathrm{ws}} - s_{\mathrm{w}}}{s_{\mathrm{s}} - s_{\mathrm{w}}}。\tag{14.2}$$

[4] C. Burns, P. Izmailov, J. H. Kirchner, B. Baker, L. Gao, L. Aschenbrenner, Y. Chen, A. Ecoffet, M. Joglekar, J. Leike, I. Sutskever, J. Wu, *Weak-to-Strong Generalization: Eliciting Strong Capabilities With Weak Supervision* In arXiv preprint arXiv:2312.09390, 2023

$g = 0$ 表示学生与弱监督者得分相同，$g < 0$ 表示学生得分更低，$g = 1$ 表示达到强监督参照；比值也可超出 $[0, 1]$，因为参照不是数学能力上限。它回答可测差距恢复多少，仍需要可信测试标签；没有这些标签的真实情境无法直接计算同一恢复率。

实验应使弱模型只标注训练样本，最终测试另保留可信标签，再同时评价弱模型、强学生与强参照。若教学测试得分分别为 0.6、0.75、0.9，恢复比例为 0.5。训练测试独立仍需保持；用于监控时，测试标签还应对应实际违反约束，而不能仅对应语言任务答对。

审核长邮件报告时，可以把判断分解为事实出处、归纳遗漏和行动授权等局部问题。分解能扩大监督范围的前提是这些局部检查共同约束整体结果。多个评价模型若共享训练数据或盲点，其一致意见也不能视为多份独立证据。

### 14.2.5　评估与监督效果的检验

邮件监控在测试样本中正确标出违规，并不意味着实际服务中的告警能够被及时处理。监督验收应分别检查判定准确性和运行作用。规则检查需对照已知状态变化，偏好模型需在未拟合的比较对上报告误差与分歧，过程评价需与实际结果比较。不同标签的验收对象不同，不能用一个评价器的高分覆盖全部要求。

运行监控还应报告漏报、误报、发现延迟与复核成本。用于决策的分数需要与实际偏离事件建立关系。训练、阈值选择和最终测试应使用不同数据，并包含真实使用中易与违规混淆的正常情况。

选定告警阈值 $\tau$ 后，可以在独立标注的测试轨迹上按固定规则 $m(v(h_t)) \geq \tau$ 逐条运行。对偏离轨迹记录是否检出、是否早于不可逆操作，对正常轨迹记录错误告警。阈值由允许漏报、误报负担和处理预算选择，不能在看过最终测试结果后反复调到有利值。

少量异常样本上的检出支持识别能力；真实发生率下可及时处理的告警队列支持运行可用性；损害前出现的告警才为干预创造机会。比较观察信息或监控方法时，需要匹配误报或复核预算，否则更多告警可能只是使用了更宽松的阈值。

**示例 14.2　低发生率下的告警负担**　设偏离发生率为 0.1%，检出率 95%，正常行为误报率 1%。10000 次行为中的真告警期望为 $10000 \times 0.001 \times 0.95 = 9.5$，误告警期望为 $10000 \times 0.999 \times 0.01 = 99.9$。真告警占全部告警约 8.7%，所以高检出率并不意味着复核队列主要由真实异常组成。

监督器本身也有故障和攻击入口。特殊输出格式可能诱发评判错误，第三方内容可能污染监控上下文。应通过独立证据、权限设计与攻击测试评估这些入口；赋予模型“审核员”身份只是提示设置。

解释质量可能影响告警，却不决定告警效果。遗漏部分内部因素的理由仍可能预测越权，而忠实描述一次局部计算也未必预测后续风险。可在相同误报预算下比较最终回答、动作记录和推理文本的检出效果，并报告记录引入的隐私成本。

旁观监控与被优化监控面对不同分布。模型不知道评分时，测试针对当前行为的识别；评分进入奖励或重试规则后，输出会向容易通过监控的区域移动。原来的漏报率需在这种优化后的输出上重新测量，第 17.2.1节将进一步从主动攻击者利用反馈调整策略的角度分析这种评估变化。

## 14.3 行为泛化与约束保持的条件

模型能按熟悉模板归档邮件，换用新语言或连续处理多封邮件后，仍可能漏掉保留要求。已测任务上的合规表现只支持这些条件下的结论。行为泛化考察新情境中的目标与约束，行为保持还涉及交互长度、版本和组件变化。要扩大结论范围，需要说明变化后哪些证据与机制仍然有效。

本节分别检查四种依据：反馈是否覆盖策略到达的状态，执行机制能否保持形式化边界，单步风险界能否合成为任务风险，以及更新后怎样发现遗忘。它们给出的结论性质不同，不能由一项平均成绩相互替代。改变行为的方法见第 14.4节，本节确定这些方法支持保持结论还需哪些条件。

### 14.3.1 基于训练覆盖的约束迁移

检验经验泛化，可以固定任务目标和授权规则，改变语言、邮件编号、标记位置、工具返回顺序与任务组合。正确动作保持一致的成对案例，有助于判断模型是否学到了规则。边界案例还应只改变授权等关键条件，使允许与禁止的动作分别出现，避免把关键词触发的拒绝误判为规则理解。

覆盖还应延伸到策略自己的错误状态。专家轨迹往往没有漏读、调用失败或任务中断后的历史，而模型运行会进入这些状态。可在隔离或受限环境中运行候选策略，再为重新读取、核查和恢复提供经验证的反馈；怎样把这些状态反馈转为训练数据，将在第 14.4.2节讲述。

这些案例减少已知状态失配，但有限数据仍不能覆盖所有未知环境。工具语义或授权规则改变时，原动作标签可能失效，应先修改任务定义和状态表示，再决定原有证据能否沿用。

### 14.3.2 基于执行机制的约束保持

行为约束中，有些规则可以由独立于模型措辞的授权记录与执行检查实现。此时需要验证状态转移保持边界，而不是要求模型每次都正确复述规则。

设 $S_{\text{safe}}$ 为符合约束的状态集，$A(s)$ 为状态 $s$ 的可执行动作，$\mathcal{T}(s,a)$ 包含模型所允许的全部后继状态。为了保证一次执行仍留在安全集合，定义

$$A_{\text{safe}}(s) = \{a \in A(s) : \mathcal{T}(s,a) \subseteq S_{\text{safe}}\}。\tag{14.3}$$

若初始状态安全，每步都有可执行安全动作，执行器只实施该集合中的动作，且真实转移被 $\mathcal{T}$ 覆盖，便可逐步归纳：安全状态经过允许动作仍到达安全状态。因此这一结论依赖状态、转移覆盖和执行权限三方面的前提（可参考第一卷“策略的实现与轨迹控制”章的“策略的约束与安全”一节中的离散状态保持条件）。

**安全屏蔽**（shielding）在学习者与环境之间检查或修正动作。Alshiekh 等由时序逻辑规范构造屏蔽器，在候选动作可能违反规范时改正它。该方法把相应规范的保持交给环境模型与执行规则，提供了区别于奖励惩罚的实现路径[5]。

[5] M. Alshiekh, R. Bloem, R. Ehlers, B. Könighofer, S. Niekum, U. Topcu, *Safe Reinforcement Learning via Shielding* In Proceedings of the AAAI Conference on Artificial Intelligence, 2018

上述教学状态模型须包含要求依赖的信息：历史条件、权限、计数器和外部副作用。遗漏这些对象，归纳证明便不代表真实系统；工具变化后也须重查转移覆盖。停止未必在所有环境中安全，安全动作存在也不保证任务最终完成。这些条件保证的是所表达的边界，不能据此推断内部目标一致。具体动作校验与执行位置见第 14.4.6节。

图 14.3把动作边界落实在执行端。应分别统计模型提出违规方案与执行器实施违规动作，以便区分生成行为和后果控制的效果。

### 14.3.3 基于风险预算的长程控制

长交互需要把局部违规与任务失败联系起来。设任务最多执行 $T$ 步，$E_t$ 为第 $t$ 步发生规定偏离，则联合界给出

$$\mathbb{P}\left(\bigcup_{t=1}^{T} E_t\right) \le \sum_{t=1}^{T} \mathbb{P}(E_t)。\tag{14.4}$$

该界不要求步骤独立，但每项边际概率必须对实际行为过程成立。若局部上界依赖部署策略访问的历史，策略变化以后应重新检查其适用条件。

给定任务容限 $\alpha$，可分配非负预算 $\alpha_t$ 并令 $\sum_{t=1}^{T} \alpha_t \le \alpha$。如果实际策略各历史下的条件违规概率都有有效上界 $\alpha_t$，对历史取期望可得到边际界，再用式 (14.4)约束任务风险。分配数字只是设定要求，不会产生概率证据。

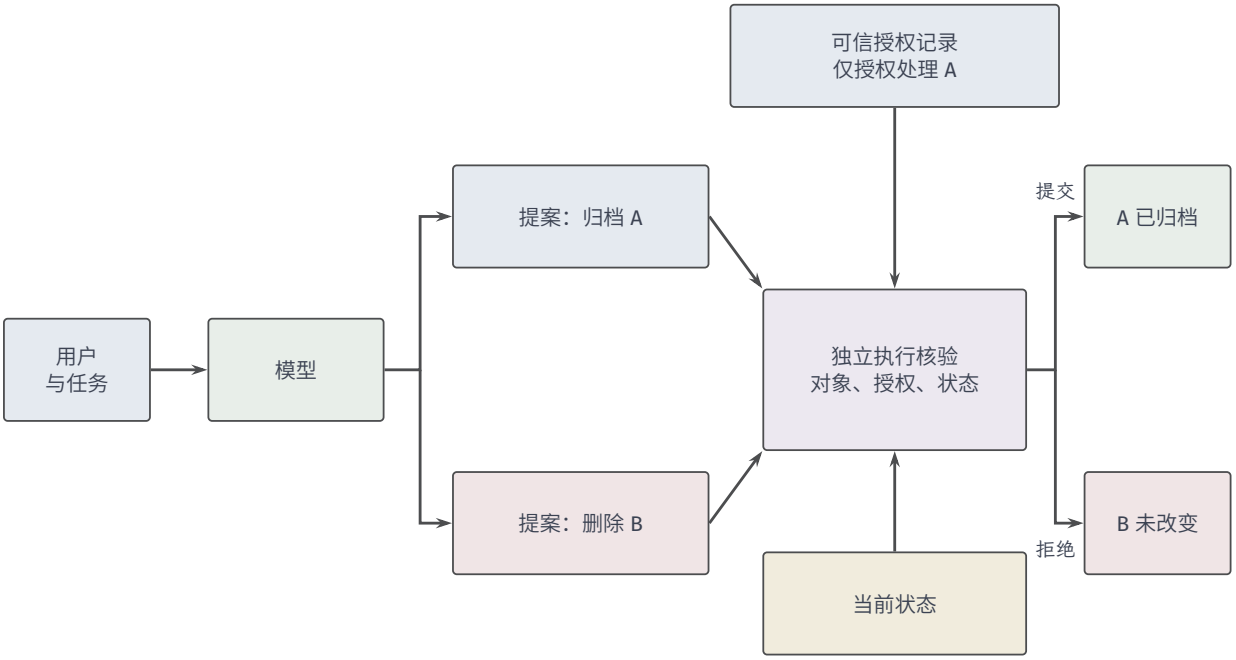


图 14.3 独立执行权限限制模型提案。可信记录只授权处理邮件 A，因此归档 A 被提交，删除 B 被拒，B 保持原状态。训练影响动作倾向，执行器则核对对象、授权与当前状态；提案不能修改许可。安全状态持续保持还需要正文中的转移覆盖与安全动作存在等前提。

提前结束且不再产生后果时，未执行事件可记为空事件；已提交但未完成的外部操作仍需计入。

例如，最多 100 步的任务若容许风险 0.01，均匀分配要求每步上界为 0.0001。短任务中的低失败率并未证明这个数值；步骤增加后也须重新分配或验证总界。重新开始交互不能使同一任务已经消耗的风险预算自动恢复。

执行状态可记录次数、累计开销、已占用的概率上界与剩余额度，在关键动作前核查下一步前提。无法满足时，应切换到具有明确安全条件的后备方案；新路线更短也仍需验证。未观察到错误不会补回已经分配的概率预算，因为预算描述的是事前风险界。

长程验收应保留完整轨迹，在不同长度与工具组合下统计至少一次违规、提前中止和总损失。只分析成功结束的轨迹会遗漏早期失败。关键节点复核能够改变风险，但其局部效果及完整过程中的累计结果仍需测量。

### 14.3.4 持续更新中的行为保持

重复发生的问题可以经复核后进入训练，补充示范或修正评价。监控标签直接回灌可能把误报学成新的拒绝规则，所以应核查标签并保留未参与回灌的测试集。

部署数据的生成过程应随样本保存：哪个策略版本产生轨迹，哪个监控器与阈值选择告警，哪些动作被阻断，以及复核或真实状态如何给出标签。仅学习告警、复核或完成样本，会把选择机制当成总体分布。可随机复核未告警轨迹；被阻断动作没有实际结果，不能因此标为安全。

旧任务回放、参考行为和参数限制分别保留不同对象，也可能保留原有错误。仅回放拒绝案例会鼓励过度拒绝，逼近错误参考模型也会复现其错误。保留集合应同时覆盖正常任务、容易混淆的合法边界和关键违规，并核验保留对象本身。第 14.4.2节给出这些保留对象对应的更新方法。

干预还会改变后续输入。频繁拒绝可能促使用户改写请求，使原监控器面临新的表达分布。更新验收因此需要包括未来输入变化，不能只检验参数更新后的同一静态样本。

微调、模型合并、量化和持续学习都可能改变关键行为。参数变化小或平均能力不变，仍允许少量高影响场景退化。每次更新应成对比较旧任务、新任务、关键边界及监控表现，并保留版本以支持定位。

验收行为保持时，应另报合法任务完成与错误干预。若违规下降只是因为模型回避所有困难任务，服务目标已经退化。将完成、错误阻断和约束违反分别统计，才能看清这种交换。

模型格式或推理方式改变，也可能让旧监控失配。更新范围需要包括可见记录、阈值、工具权限与重试规则，并检查这些组件组合后的行为。

### 14.3.5 泛化与保持效果的检验

新语言、组合任务和长行动链都可能使熟悉提示中的行为改变。能力不足与优化错误代理可能造成相同的失败结果，因而不能仅凭一次输出确定模型意图。评价应固定任务条件，比较有关证据能够排除哪些解释。

情境变化还可能触发平常测试中未出现的行为。Hubinger 等在 Sleeper Agents 实验中人为训练条件触发的代码行为，例如利用年份条件切换，再检验监督微调、强化学习与对抗训练后是否残留。在若干设置中触发行为仍保持；这是关于构造模型与训练方法的实验，不能用于估计自然部署模型的发生率[6]。

触发异常也可以由攻击者植入，第 17.1节将讨论这种后门。对行为保持的检验应覆盖角色、工具、持续时间、是否显露评价身份及其组合，确认纠错后有关触发条件是否仍能改变行为。

测试应保留任务中真实存在的行动机会。没有工具权限时观察不到越权调用，不能支持获得权限后的行为结论；额外告诉模型当前可以违规，也会改变被测条件。应记录权限与提示，使结果对应明确的情境。

[6] E. Hubinger, C. Denison, J. Mu, M. Lambert, M. Tong, M. MacDiarmid, T. Lanham, D. M. Ziegler, T. Maxwell, N. Cheng, A. Jermyn, A. Askell, A. Radhakrishnan, C. Anil, D. Duvenaud, D. Ganguli, F. Barez, J. Clark, K. Ndousse, K. Sachan, M. Sellitto, M. Sharma, N. DasSarma, R. Grosse, S. Kravec, Y. Bai, Z. Witten, M. Favaro, J. Brauner, H. Karnofsky, P. Christiano, S. R. Bowman, L. Graham, J. Kaplan, S. Mindermann, R. Greenblatt, B. Shlegeris, N. Schiefer, E. Perez, *Sleeper Agents: Training Deceptive LLMs that Persist Through Safety Training* In arXiv preprint arXiv:2401.05566, 2024

邮件迁移测试可以逐项改变请求语言、重要标记位置或额外工具，同时保持应采取的动作和保留条件不变。成对结果帮助定位单项失配；随后还需检查多项共同变化，以覆盖真实使用中的组合。

过去的正常任务、合法易混淆任务与损失案例可作为回归集合，检查纠错是否保留；另加入未见表达测试迁移。反复用于开发的回归集合已参与方法选择，其成绩应与新独立测试分别报告。

可以固定任务、工具返回与随机条件，让旧版和新版成对运行，记录双方成功、仅旧版成功、仅新版成功和双方失败。仅新版成功反映收益，仅旧版成功反映遗忘，二者可能在相同平均分中抵消。还应让旧监控检查新轨迹；若需要重设阈值，阈值选择与最终测试继续分开。

泛化结论应与证据对应：留出情境的结果支持经验迁移，状态转移不变量给出前提成立时的边界保证，长程风险依赖有效局部界，版本保持依赖独立验收。没有被覆盖的条件不能用平均成绩填补。

## 14.4 行为干预

观察到邮件误删或未授权转发后，仅报告错误并不会改变后续行动。行为干预依据目标、约束或监督证据改变行动及其后果。它可以在部署前影响学习，也可以在运行中补充信息、改变候选或限制执行。本节把前面的保持条件转为具体操作，并说明如何判断操作是否达到目的。

干预选择先考虑出现问题的时机，再确定作用位置。下面依次介绍数据与参数、输入上下文、内部计算、候选交付，以及动作执行与恢复；每种方式都需要说明它实际改变了哪个对象。

### 14.4.1 干预时机与方案选择

反复出现的行为偏差可在部署前通过训练修正，单次请求中的信息不足则常需立即补足。运行时可以在告警或触及边界时介入，事后干预处理已经产生的状态变化。时机应与问题来源及后果的可逆性相匹配。

信息不足但后果较轻时，可先澄清；可修订的内容可重新生成；权限冲突需由执行端限制；损失高且不可逆的行动可能需要停止或人工接管。选择时应评估操作能否在后果发生前生效。

设继续执行的损害概率为 $p(h)$、损害成本为 $c_{\mathrm{harm}}$，停止成本为 $c_{\mathrm{stop}}$。若停止完全避免这项损害，比较期望损失便得到 $p(h)c_{\mathrm{harm}} > c_{\mathrm{stop}}$ 时应停止。干预效果不完全或成本结构不同，应重算各选择的后果。风险概率需有对应事件和估计依据，监控分数未经校准不能直接代入。

教学例中，误删损失为 100，等待复核成本为 2，因而概率阈值为 0.02。估计 0.03 时继续的期望损失为 3，大于暂停成本；估计 0.005 时损失为 0.5，

按这一比较可继续。明确违反授权的动作应由权限规则排除，不能因为概率估计较低而放行；损失阈值用于允许决策之间的不确定后果比较。

人工接管要有必要上下文、判断时间以及停止和纠正权限。仅增加确认按钮并未改善判断依据，还可能把同一信息缺口传给人。验收应检查人是否能够在所给条件下完成接管。

### 14.4.2 训练阶段的数据与参数干预

若助手在多次任务中跳过重要标记核查，就需要让正确程序在后续请求中更容易出现。训练干预修改数据、评价目标或策略参数，使作用延续到后续任务。缺少正确程序时可以补充示范，代理评价遗漏关键要求时则应先修正反馈或约束。继续优化错误目标，会加强前述代理偏差。

示范记录希望出现的路径，评价信号区分候选，参数更新改变路径概率。第 14.2.2节说明了反馈来源与粒度，这里进一步解释它怎样改变生成策略。原版本和独立验收集应保留，以便辨别收益与退化。

**通过示范修正行为** 助手若没有学会“先读取重要标记，再归档并核查检索”的程序，可以用正确路径提供示范。**监督微调**（supervised fine-tuning, SFT）在给定历史下提高示范输出的概率，用于传递格式、操作程序和数据覆盖中的约束。它所支持的行为范围来自示范分布，未出现的边界仍需检验。

设示范回答 $y$ 包含词元 $y_1, \dots, y_m$。对任务上下文 $\boldsymbol{x}$ 及示范分布 $D_{\text{demo}}$，以参数为 $\theta$ 的策略拟合序列，可最小化

$$L_{\text{SFT}}(\theta) = -\mathbb{E}_{(\boldsymbol{x},y)\sim D_{\text{demo}}} \sum_{t=1}^{m} \log \pi_\theta(y_t \mid \boldsymbol{x}, y_{<t}), \tag{14.5}$$

$y_{<t}$ 为当前词元之前的示范前缀。逐词元负对数似然提高示范路径的概率，但训练条件来自示范，部署条件来自模型已生成的前缀。早期偏差可能使后续生成进入数据外状态，因此还须验证完整交互。

示范样本应对应模型当时可见的信息与期望的下一步输出。邮件路径可依次读取标记、调用归档和确认检索。文本工具调用的名称与参数也是策略输出，工具返回则成为下一步输入，应保留真实来源。式 (14.5)使示范路径更可能出现，不能授权模型编造工具状态。

SFT 产生的是生成策略。单条 $A$ 示范不提供 $A$ 比 $B$ 好多少的相对分数，也未列举全部违规 $C$。可固定任务要求，改变编号、标记位置与工具返回，让策略自行完成全程，再核查动作和状态，判断学到的是程序还是措辞。

专家轨迹未必覆盖学习策略的错误状态。数据集聚合（Dataset Aggregation, DAgger）反复运行当前策略，由专家为实际访问的状态标注动作，

再把样本加入训练。Ross 等在相应在线学习假设下分析了这种训练分布修正，其结论不等于任意新环境中的安全保证[7]。邮件任务可在隔离环境中收集漏读标记、返回缺失后的历史，为恢复读取、澄清或停止提供示范。

**通过评价反馈调整策略** 比较标签需要通过策略更新才能影响生成。可以先拟合奖励模型再优化策略，也可以直接用成对偏好调整概率。两条路线共享反馈误差与覆盖边界，省去独立奖励模型并不会使原标签变得更准确。

人类反馈强化学习（reinforcement learning from human feedback, RLHF）常把人的少量比较扩展为奖励模型对新行为的评分，再用评分更新策略。Christiano 等通过行为片段比较学习偏好预测，将其用于强化学习奖励。相对比较有时比提供示范方便，但判断分歧、遗漏与外推误差也进入策略学习，偏好拟合的有效性需与最终使用效果分别验收[8]。

这一过程可以循环进行：策略生成候选，人比较部分候选，奖励模型吸收新标签，再指导下一轮策略更新。持续收集当前策略数据有助于覆盖新出现的行为，也相应增加比较和复核成本。

一次更新先固定奖励模型，采样完整回答或轨迹并计算评分，再根据样本相对基准的优劣调整生成概率。高于基准的样本得到提高概率的信号，低于基准者得到相反信号。行为变化由策略参数承担；仅修改奖励模型不改变生成策略。重新采样后的候选用于检查这种概率调整的实际结果。

InstructGPT 先以人工示范形成初始策略，再以回答排序训练奖励模型，最后用近端策略优化（proximal policy optimization, PPO）更新策略并限制相对参考模型的偏离，还混入预训练语言建模目标以减轻部分能力退化。研究展示了特定标注群体反馈可以改善通用语言模型的指令回答，模型仍可能产生事实错误等失败；这些结果未统一所有群体的要求[9]。

上述流程中，奖励模型评价采样回答，策略更新提高较高奖励行为的出现概率。PPO 裁剪进入代理目标的概率比，使过大的比率变化不再带来相同优化收益；它并未硬性限制更新后所有输入与动作的比率。优化过程平稳只涉及更新性质，有偏奖励仍可能在多次平稳更新中导致行为偏离。

为限制策略进入奖励缺少可靠支持的区域，可惩罚它相对于参考策略 $\pi_{\text{ref}}$ 的偏离。固定上下文 $\boldsymbol{x}$，以 $\beta > 0$ 控制保守程度。为得到有限目标，下面只考虑期望奖励与 KL 均有限、且只在参考策略赋予正概率的回答上分配概率的候选策略 $\pi$。一种理想化目标为

$$\max_{\pi} \ \mathbb{E}_{y\sim\pi}[r(\boldsymbol{x}, y)] - \beta D_{\text{KL}}(\pi \| \pi_{\text{ref}}), \qquad \beta > 0。 \tag{14.6}$$

[7] S. Ross, G. Gordon, D. Bagnell, *A Reduction of Imitation Learning and Structured Prediction to No-Regret Online Learning* In Proceedings of the Fourteenth International Conference on Artificial Intelligence and Statistics, 2011, pp. 627–635

[8] P. F. Christiano, J. Leike, T. B. Brown, M. Martic, S. Legg, D. Amodei, *Deep Reinforcement Learning from Human Preferences* In Advances in Neural Information Processing Systems 30, 2017, pp. 4299–4307

[9] L. Ouyang, J. Wu, X. Jiang, D. Almeida, C. L. Wainwright, P. Mishkin, C. Zhang, S. Agarwal, K. Slama, A. Ray, J. Schulman, J. Hilton, F. Kelton, L. Miller, M. Simens, A. Askell, P. Welinder, P. Christiano, J. Leike, R. Lowe, *Training Language Models to Follow Instructions with Human Feedback* In arXiv preprint arXiv:2203.02155, 2022

奖励项鼓励高分回答，KL 项抑制远离参考分布。增大 $\beta$ 通常使更新更保守，但参考策略可能包含错误，KL 距离也未定义禁止动作。因此仍需独立的约束证据。

成对数据也可以直接用于调整回答概率，而不先拟合独立奖励模型。**直接偏好优化**（direct preference optimization, DPO）利用正则化奖励目标与策略之间的关系，将比较标签直接写入策略损失。在参考策略支持上的奖励有界时，式 (14.6)的最优策略按参考概率乘以 $\exp(r(\boldsymbol{x}, y)/\beta)$ 重新加权。奖励差因而可改写为最优策略相对参考策略的对数概率比差的 $\beta$ 倍，同一上下文的归一化项在相减时消去；DPO 据此用当前策略参数化 Bradley–Terry 比较模型。对当前策略和参考策略均赋予正概率的两个回答，记其对数概率比差为

$$d_\theta(\boldsymbol{x}, y^+, y^-) = \log \frac{\pi_\theta(y^+ \mid \boldsymbol{x})}{\pi_{\text{ref}}(y^+ \mid \boldsymbol{x})} - \log \frac{\pi_\theta(y^- \mid \boldsymbol{x})}{\pi_{\text{ref}}(y^- \mid \boldsymbol{x})},$$

对偏好样本平均最小化 $-\log \sigma(\beta d_\theta)$，即可在这种模型关系下更新策略，省去独立奖励模型的训练和调用[10]。

该损失随 $d_\theta$ 增大而减小，因而鼓励拉开优选回答 $y^+$ 与另一回答 $y^-$ 的相对概率。它不直接规定每个回答的绝对概率怎样变化。比较信息、噪声和覆盖限制仍存在；离线数据只覆盖旧策略输出时，新策略进入的区域可能缺少标签。$\beta$ 与参考分布决定学习尺度，训练损失下降后仍要检查实际行为和过度优化。

持续更新可通过数据回放保留旧经验，通过输出约束保留经核验的参考行为，或通过参数惩罚限制重要权重变化。输出约束需明确任务范围、分布距离或行为一致率及阈值。弹性权重巩固（elastic weight consolidation, EWC）依据旧任务估计的重要性，加强对重要参数偏离旧值的惩罚，能够缓解相应遗忘，但旧任务重要性不涵盖全部行为要求[11]。三种保留对象均需按第 14.3.4节复查正常任务、合法边界与关键违规。

图 14.4显示评分进入 RLHF 更新、比较对进入 DPO 损失的不同接口。两者都应区分被更新的当前策略和固定参考策略，并另用行为结果验收。

### 14.4.3 推理输入与上下文的干预

当前请求缺少信息或要求含糊时，可以先调整上下文：请求澄清，检索证据，刷新工具状态，或提供已确认的授权记录。这种干预改变此次决策的输入，不必等待参数更新，也不能据此推断所有任务都已修复。

重要标记不可见时，邮件助手应重新读取或请求确认，不能根据语气猜测。清理旧邮件与保留规则冲突时，应取得足以确定允许动作的澄清。补充证据的范围仍由本次任务权限限制。

[10] R. Rafailov, A. Sharma, E. Mitchell, S. Ermon, C. D. Manning, C. Finn, *Direct Preference Optimization: Your Language Model is Secretly a Reward Model* In arXiv preprint arXiv:2305.18290, 2023

[11] J. Kirkpatrick, R. Pascanu, N. Rabinowitz, J. Veness, G. Desjardins, A. A. Rusu, K. Milan, J. Quan, T. Ramalho, A. Grabska-Barwinska, D. Hassabis, C. Clopath, D. Kumaran, R. Hadsell, *Overcoming Catastrophic Forgetting in Neural Networks* In Proceedings of the National Academy of Sciences, 2017

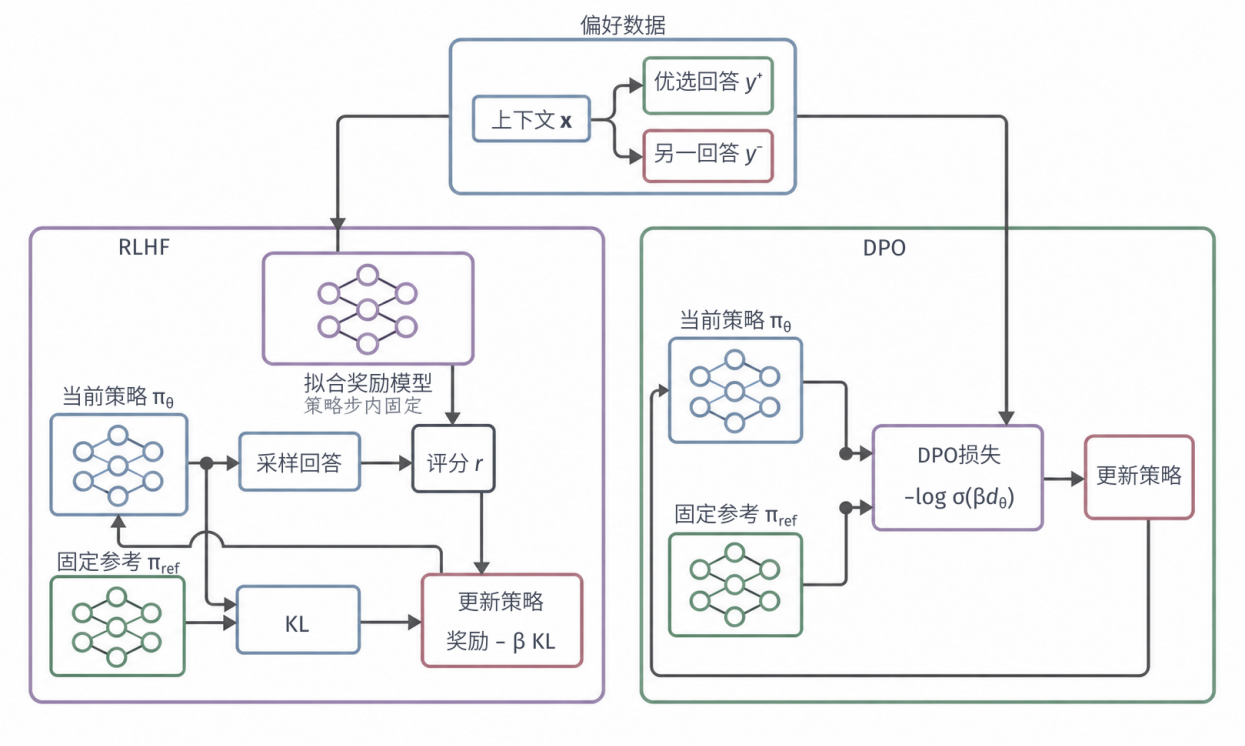


图 14.4 相同偏好数据进入两种策略更新。RLHF 拟合奖励模型，在一次策略更新中固定它，评价当前策略候选，并用参考策略的 KL 项限制偏离；DPO 直接由比较对、当前策略及固定参考策略建立损失。省去奖励模型不会消除覆盖缺口与标签噪声。

长交互可将目标、已确认约束、已执行动作和未决问题保存在可核查状态中，在高影响操作前从真实工具刷新。摘要能够压缩历史，却可能丢失条件；授权与关键状态应有可信记录，避免只依赖模型自行生成的总结。

验收输入干预需要在同一任务上比较动作与结果，确认新增证据是否实际参与决策。提示更长或回答重复约束，只说明文本发生变化。仍无法补足关键信息时，应使用满足条件的后备方式或停止。

### 14.4.4 推理计算过程的干预

补齐标记与授权信息后，助手仍可能生成违规计划；一种进一步尝试是直接修改生成时与行为有关的内部表示。设某层激活为 $\boldsymbol{z}$，从标签中估计与目标属性有关的方向 $\boldsymbol{v}$，可用 $\boldsymbol{z}' = \boldsymbol{z} + \alpha\boldsymbol{v}$ 改变后续计算，$\alpha$ 控制强度。输入干预改变模型看见什么，表示干预改变它如何计算，候选筛选则在生成后改变交付选择。

Li 等利用真实性标签分析注意力头表示，选择部分头并调整相关方向，在 TruthfulQA 等设置中测量回答变化。实验提供了表示干预的实证例子；相关方向并非通用诚实开关，真实性、任务帮助程度和覆盖仍需分别评估[12]。

[12] K. Li, O. Patel, F. Viégas, H. Pfister, M. Wattenberg, *Inference-Time Intervention: Eliciting Truthful Answers from a Language Model* In arXiv preprint arXiv:2306.03341, 2023

一种教学构造先固定层和激活位置，收集经核验的合规与违规行为，求均值 $\bar{\boldsymbol{z}}_{\text{ok}}$、$\bar{\boldsymbol{z}}_{\text{bad}}$，再将非零差向量归一化为 $\boldsymbol{v}$。这样 $\alpha > 0$ 指向合规标签一侧；使用分类器法向量时也要确定朝向。保持参数固定，在验证集尝试少量强度，同时比较违规与任务完成，选定后冻结并在新任务上测试。这个流程解释方向估计与强度选择，不是前述论文的完整复现。

邮件方向的标签应来自实际保留与授权结果，而非回答是否出现安全字样，并控制难度和长度。零干预、反向干预与匹配尺度的随机方向可作为对照。若违规下降伴随大量合法任务拒绝，应检查干预改变的是约束行为还是整体输出倾向。

第 15.3.2节也将使用内部干预，但解释任务要求检验表示怎样参与行为。这里主要检验改变表示是否改善结果。两类证据可以互相补充，效果改善本身仍不足以给出完整机制解释。

### 14.4.5 生成结果的筛选与修订

候选生成没有外部副作用时，可以在交付前拒绝、修订或选择输出。筛选改变交付规则，无须更新参数；行动权限仍需在执行接口中规定，不能由一个被选计划代替。

筛选器读取尚未执行的候选与证据，输出一个候选或无可交付结果。邮件计划 $A$、$B$、$C$ 可先按保留规则排除 $C$，再按用户偏好比较前两者。无合

适候选时应澄清或停止；计划通过内容筛选后，实际工具调用仍须核查授权。

反复采样直到监控放行，可能找到监控器的盲点。交付分布随选择规则变化，因此应固定重试次数、失败处理与筛选规则，再评价整个过程。重新生成的输出也必须接受检查。

best-of-$n$ 从多个候选中选取最高分回答，生成模型提供候选，评价器决定交付结果。候选中存在合适回答只是一个前提，评价器还需正确识别它。考察候选数 $n$ 的作用时，应固定生成模型与评价器，报告随 $n$ 增加的收益、评价误差和成本。比较不同评价器时，则应匹配候选数与评价预算，以免把额外计算带来的收益归于评价方法。

二元过滤器的通过后风险可由条件概率计算。设原分布违规比例为 $\rho$，违规与正常样本的通过概率分别为 $u$、$v$，分母为正时有

$$\mathbb{P}(\text{违规} \mid \text{通过}) = \frac{\rho u}{\rho u + (1-\rho)v}。 \tag{14.7}$$

教学值 $\rho = 0.1$、$u = 0.05$、$v = 0.9$ 给出约 0.61%。降低漏检有助于减少风险，但正常通过率也进入分母；只报告 $u$ 无法评价对正常任务的拒绝代价。

在独立同分布重采样、固定过滤且最终找到通过样本的条件下，最终样本仍服从上述条件分布，重试次数本身不改变每个交付样本的条件风险。生成若已有副作用，总风险可能随尝试增加；自适应重试或依据评分改写候选，也不再满足固定分布假设。

### 14.4.6 行动执行与损害恢复

生成干预以降低提议违规动作的概率为目标，执行干预则决定提议能否产生外部后果。工具授权与状态恢复需要在动作层落实，才能对应真实操作边界。

落实式 (14.3)时，执行器先解析动作、对象与参数，再查询独立授权记录。重要邮件删除和未授权转发应被阻断，合法归档仍需使用当前状态核查。执行器将成功结果或明确的拒绝原因返回模型；模型不能自行修改授权依据。第 17.3.4节将进一步检验攻击者能否伪造、绕过或组合利用这些执行条件。

表示控制可以减少不当输出，但限制某收件人访问某文件需要明确的权限检查。对于不可逆操作，应同时观察生成是否改善和执行是否越权，以免把较低提议概率当成硬性访问限制。

恢复要依据后果的可逆性设计：尚未实施的操作可以撤销，本地状态可能恢复，已经披露的信息则未必能够收回。应尽量在不可逆后果前介入，并记录阻止失败时留下的实际损失。

执行验收可固定模型请求，分别测试合法请求、越权对象与异常参数，检查阻断前是否已经产生副作用。恢复验收应核对真实状态和残留损失；系统输出恢复声明只构成日志记录。

### 14.4.7 干预效果与代价的验证

邮件助手的训练分数提高后，仍需检查重要内容是否保留，以及合法整理是否完成。干预效果由同一目标和约束下的行为变化判断。训练损失、风险评分与拒绝数量是中间观察，不能替代实际任务结果。使用参考策略时，还需核查其行为是否符合当前要求。

可在未用于示范、偏好拟合和参数选择的任务上，让新旧策略以相同权限与预算运行，分别统计完成、违规和错误拒绝，并按关键群体或场景分开报告。这种完整交互比较揭示训练指标未体现的后果。

奖励改进需与独立状态证据对照。邮件保留和授权发送可以由操作记录核查，同一奖励模型再评分仍保留原代理误差。比较结果与过程反馈时，应匹配监督预算并用实际任务结果作最终依据。

一次验收可以包含三组分开记录的观察。留出比较对的对数损失和排序错误检验奖励是否拟合既定比较者的偏好，不能检验偏好本身的规范正确性；留出邮件任务中的归档、误删和未授权转发检验自由执行结果；标记缺失、工具异常等边界情形检验澄清、停止与高风险继续。第一组改善而第二组退化提示外推或优化问题，平均任务改善而边界违规则仍需限制权限。容许错误率与最低完成要求应在测试前设定，并考虑样本量与估计误差。

训练交互也属于受约束过程。最终策略减少危险动作，并不消除训练探索已造成的损失。仿真、离线数据、受限动作与安全参考行为可以限制探索后果，同时应说明这些训练环境与真实使用之间的差距。

运行干预可在相同任务上比较无干预、仅筛选、仅表示调整和完整组合，报告完成、违规、错误阻断、复核与延迟。候选阶段的副作用和总尝试次数应计入成本。训练干预则还需检验旧任务保持与新任务收益。

告警出现、干预生效与不可逆操作发生的时间需要分别记录。判断正确但响应太迟，应修正响应机制；正常任务被及时阻断，则应检查阈值或授权判据。区分这些事件才能把修订落实到具体环节。

## 14.5 本章小结

整理目标要求助手提高信息可用性，行为约束则界定操作对象、核查条件与不可补偿后果。奖励和偏好提供可优化信号，实际状态与操作记录提供结果证据；它们各自承担的作用需要保持明确。

评价应分别观察结果、边界、证据使用与不确定处置。状态核验、人工比较、原则评价和过程标签提供不同粒度的反馈，监控把可见记录转成告警，可扩展监督尝试克服判断能力限制。每个环节都需要自己的验收对象。

行为保持依赖相应条件：状态覆盖支持经验迁移，执行不变量在模型和权限前提成立时保持边界，有效局部概率界支持长程风险控制，独立成对测试检查更新收益与遗忘。这些证据支持的范围应随结论一起报告。

干预可以作用于参数、上下文、内部计算、候选交付或执行状态。选择应依据偏离来源与后果，并尽量在不可逆操作前生效。干预后输入和行为分布可能改变，因而任务完成、约束、监控与过度拒绝都需重新验证。

**延伸阅读** 继续阅读 Christiano 等与 Ouyang 等的工作，可以追踪比较标签如何进入奖励模型与策略更新。应沿流程区分偏好拟合误差、策略优化效果和最终行为证据，避免以某个训练环节的改进代替完整验收[13,14]。

宪法式人工智能与弱到强泛化分别研究原则怎样扩大反馈、能力有限的监督者怎样指导更强模型。二者提供不同监督路径，阅读时均应检查评价者覆盖与独立测试条件[15,16]。

[13] P. F. Christiano, J. Leike, T. B. Brown, M. Martic, S. Legg, D. Amodei, *Deep Reinforcement Learning from Human Preferences* In Advances in Neural Information Processing Systems 30, 2017, pp. 4299–4307

[14] L. Ouyang, J. Wu, X. Jiang, D. Almeida, C. L. Wainwright, P. Mishkin, C. Zhang, S. Agarwal, K. Slama, A. Ray, J. Schulman, J. Hilton, F. Kelton, L. Miller, M. Simens, A. Askell, P. Welinder, P. Christiano, J. Leike, R. Lowe, *Training Language Models to Follow Instructions with Human Feedback* In arXiv preprint arXiv:2203.02155, 2022

[15] Y. Bai, S. Kadavath, S. Kundu, A. Askell, J. Kernion, A. Jones, A. Chen, A. Goldie, A. Mirhoseini, C. McKinnon, C. Chen, C. Olsson, C. Olah, D. Hernandez, D. Drain, D. Ganguli, D. Li, E. Tran-Johnson, E. Perez, J. Kerr, J. Mueller, J. Ladish, J. Landau, K. Ndousse, K. Lukosuite, L. Lovitt, M. Sellitto, N. Elhage, N. Schiefer, N. Mercado, N. DasSarma, R. Lasenby, R. Larson, S. Ringer, S. Johnston, S. Kravec, S. El Showk, S. Fort, T. Lanham, T. Telleen-Lawton, T. Conerly, T. Henighan, T. Hume, S. R. Bowman, Z. Hatfield-Dodds, B. Mann, D. Amodei, N. Joseph, S. McCandlish, T. Brown, J. Kaplan, *Constitutional AI: Harmlessness from AI Feedback* In arXiv preprint arXiv:2212.08073, 2022

[16] C. Burns, P. Izmailov, J. H. Kirchner, B. Baker, L. Gao, L. Aschenbrenner, Y. Chen, A. Ecoffet, M. Joglekar, J. Leike, I. Sutskever, J. Wu, *Weak-to-Strong Generalization: Eliciting Strong Capabilities With Weak Supervision* In arXiv preprint arXiv:2312.09390, 2023

第 15 章

# 可解释性

一封邮件被模型拦截后，解释可能服务于三种问题：用户询问哪些内容触发判断，开发者排查模型是否使用了不稳定页脚，受影响者寻找恢复业务的行动。第一种固定一次输出，第三种要求可行补救；第二种需先指定邮件范围与依赖指标，也可以从单次误拦提出假设，再在总体样本中检验。解释的证据要随问题确定，特征热力图不能自动覆盖这些用途。

按第 10章的三层架构，可解释性主要提供证据能力，支持理解、质疑与补救。属性或规范层先确定需要解释的行为和用途，生命周期层再检查解释可以向谁公开、版本变化后是否有效以及有意规避下能否保持。解释本身也因此需要明确使用条件。

**可解释性**（interpretability）研究人能否通过适当表示与证据理解模型行为。第 12章用模板变化暴露捷径，前一章评价行为并设置约束，这里进一步定位行为依据。一次失效测试只能提出解释问题，还需相应方法核验。本章先区分目的与范围，再介绍整体和单次解释、质量检查及行动补救；第 11章的预测可靠性为这些解释提供相关但不同的证据。

## 15.1 模型的可解释性

### 15.1.1 解释对象决定证据

解释首先应说明解释什么、交给谁，以及支持什么判断。开发者可能需要内部激活和训练样本，普通使用者可能只需相关因素及适用限制，寻求补救的人则需要行动条件。信息的粒度应与任务匹配，不能按数量多少判断解释是否有用。

模型行为、计算机制与现实因果关系也需分开。年龄与输出相关是行为描述；在模型输入中修改年龄，可以检验模型如何使用字段；现实中改变年龄通常无法作为行动，更无法由字段试验推出后果。使用“影响”时，应指出比较的对象和干预发生在哪个系统中。

### 15.1.2 整体解释与单次解释

**整体解释**（global explanation）以可理解形式概括明确输入集合或参考分布上的判断规律，例如可执行规则、特征响应曲线和概念作用统计。整体指声明的覆盖范围，可能是全部部署邮件，也可能是某种语言或业务类型。它不要求逐项列出内部计算，但平均摘要不能因此被推广到每个输入。

**单次解释**（local explanation，常译“局部解释”）固定一项输出，例如当前邮件的拦截结果。方法可以比较输入邻域、相对基准的分数差或某次运行中的计算作用，几何邻域只是可能的选择。两类解释都需要可核查证据；整体主张要交代总体覆盖，单次主张则要固定参照、邻域或运行条件。

准确的整体加性规则可通过代入当前特征解释一次预测；多次归因也可在定义固定后汇总为总体摘要。反向作用的子群可能在均值中抵消，单个案例也不能支持普遍规律。整体或单次范围与参数访问条件是独立维度，输入输出查询可以用于两者。

> **示例 15.1　同一规则的整体与单次说明**　设教学邮件评分器使用二元特征 $x_1$ 和 $x_2$，分别表示支付要求与可执行附件，规则为 $f(x_1, x_2) = 1 + 2x_1 + 4x_2$，分数至少为 6 时隔离。这里分数并非概率。整体说明给出基准、两项增量和阈值，覆盖四种组合；当前 $(1, 1)$ 的单次说明则代入得到 $1 + 2 + 4 = 7$，相对 $(0, 0)$ 贡献为 2 和 4。代入解释了本次计算，要断言真实模型的整体规则还须取得结构或查询证据。

图 15.1分别展示规则范围和单次代入。左侧覆盖四种输入，右侧只固定当前组合，两者承担不同的核验任务。

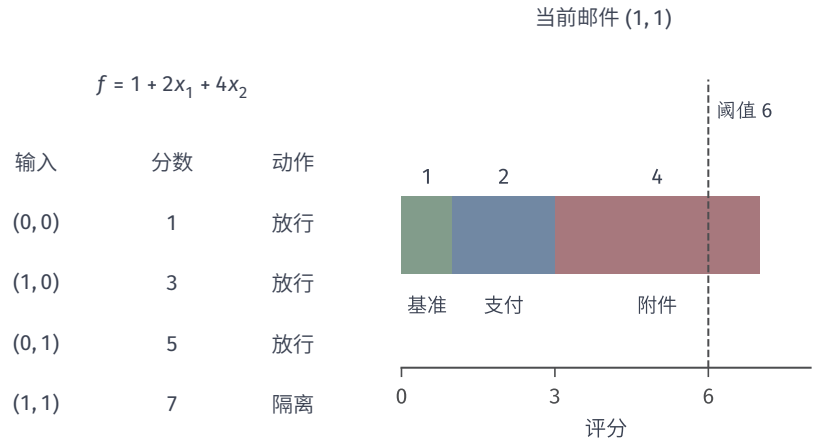


图 15.1　示例 15.1的规则覆盖与代入。左侧列出四种组合的规则，右侧对 $(1, 1)$ 计算基准 1 加贡献 2、4，得到 7 并与阈值 6 比较。计算分数不作概率解释，特征贡献也未表达现实因果作用；单次代入与整体覆盖分别需要核验。

### 15.1.3 解释的表示与证据条件

结构易于追踪还要求特征含义明确。稀疏线性式或短规则表若操作的是上万个未命名嵌入维度，使用者仍难以理解。复杂模型的局部行为也可能由简单规则准确近似，但近似范围需要限制在已验证区域。

可用信息决定能够提出的证据：输入输出查询支持行为近似，参数与激活访问支持机制假设，重新训练则支持更直接的数据影响检验。阅读后续方法时，应先核对所需访问条件，再判断它能回答的问题。

解释还隐含参照。当前邮件为何被拦而相似邮件没有，是输入比较；为何隔离而非人工复核，是行动比较。两种问题需要不同背景、分数与约束，同一归因算法也会随基准改变答案。交付时应列明输出、接收者、支持的判断或行动、参照、输入范围及允许变化的因素。

## 15.2 整体行为的解释

整体解释可围绕计算结构、输入作用和语义概念展开。结构交代规则如何组合输出，输入分析检查可观察因素的变化，语义分析检验这些因素对应的概念。三方面可以结合，例如可读结构通过命名概念计算；以下分类依据主要解释对象，不把它们当成互斥模型类型。

### 15.2.1 基于模型结构的解释

解释整套计算规则有两条途径：使用可读的实际预测器，或在训练后拟合可读代理。前者需要验证任务表现和结构理解，后者除可理解性外，还需检验与原模型的符合程度。规则来自哪个模型应在解释中明确。

**广义加性模型**（generalized additive model, GAM）把预测分解为单特征函数，以便逐项查看：

$$f(\boldsymbol{x}) = \beta_0 + \sum_{j=1}^{d} f_j(x_j). \tag{15.1}$$

$\beta_0$ 为基准，$f_j$ 描述第 $j$ 项特征响应；回归时 $f$ 可直接作为预测，二分类时可作为对数几率并经逻辑函数转为概率。各函数需固定中心化约定，例如训练分布均值为零。曲线斜率表示模型敏感性，样本覆盖则帮助区分有数据支持和估计不稳的区域[1]。

相加结构不能表示所有交互。例如，支付要求与附件各自出现可能正常，共同出现才改变风险判断。Lou 等在单变量项之外加入少量 $f_{j,k}(x_j, x_k)$，用二维曲面表示条件作用。训练需要选择交互并控制复杂度，解释也应同时展示单项曲线和交互曲面[2]。

[1] T. Hastie, R. Tibshirani, *Generalized Additive Models* In Statistical Science, 1986, vol. 1, no. 3, pp. 297–310

[2] Y. Lou, R. Caruana, J. Gehrke, G. Hooker, *Accurate Intelligible Models with Pairwise Interactions* In Proceedings of the 19th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 2013

树与规则同样可以追踪路径，但数量、重复条件和深度会增加阅读负担，只展示常见路径还会遗漏低频分支。应在具体任务中同时比较预测损失与使用者的判断表现，再确定可读结构是否足够。模型复杂程度本身不能替代这种比较。

实际预测器使用真实标签，在加性、平滑性或深度等结构限制下训练。训练固定后，解释展示函数、阈值和交互怎样组合输出。可理解性来自能够追踪的规则及特征，不能仅由训练方法名称判断。

已训练复杂模型可在声明分布上建立**整体代理**（global surrogate）。从该范围抽取输入，查询原模型 $f$，再用其分数拟合可读模型族 $G$ 中的浅树、规则或加性模型。令 $\Omega$ 惩罚复杂度，$\lambda \geq 0$ 控制权衡，一种目标为

$$\hat{g} = \arg\min_{g \in G} \left\{ \frac{1}{n} \sum_{i=1}^{n} \left[ f(\boldsymbol{x}_i) - g(\boldsymbol{x}_i) \right]^2 + \lambda \Omega(g) \right\}. \tag{15.2}$$

拟合对象是 $f(\boldsymbol{x}_i)$，所以用真实标签 $y_i$ 另训小模型并不自动形成解释。分类代理可以拟合概率或类别，所选目标决定保留的是分数变化还是决策边界。

代理应交付实际规则，并在另留查询样本上比较 $g$ 与 $f$。示例 15.1的教学规则可由先看附件、再看支付要求的树复述；“有附件就隔离”却会在 $(0, 1)$ 上出错。整体平均一致率达到预设阈值后，也须检查关键业务分支；可提高复杂度或收窄范围，但同时报告增加的理解负担。

### 15.2.2 基于输入的解释

代理给出可重新计算的近似规则，输入摘要则只回答特定作用问题。可以研究特征变化时分数如何响应，也可以破坏信息后比较任务损失。前者描述函数形状，后者描述固定模型对该信息的性能依赖，所需标签与判断尺度不同。

**响应形状与交互** 部分依赖（partial dependence, PD）把目标特征固定，对其他特征取平均[3]。设输入参考分布为 $P_{\text{ref}}$，$\boldsymbol{X} \sim P_{\text{ref}}$，对其支持范围中的 $t$ 定义

$$\mathrm{PD}_j(t) = \mathbb{E}_{\boldsymbol{X}_{-j} \sim P_{\text{ref},-j}} f(t, \boldsymbol{X}_{-j}).$$

$\boldsymbol{X}_{-j}$ 为其他特征，$P_{\text{ref},-j}$ 为相应边缘分布。这个定义固定了被替换字段和平均总体，曲线应随这两项条件解读。

经验曲线从参考总体采样，在每个 $t$ 处把所有样本第 $j$ 项替换后查询模型，计算

$$\widehat{\mathrm{PD}}_j(t) = \frac{1}{n} \sum_{i=1}^{n} f(t, \boldsymbol{x}_{i,-j}).$$

[3] J. H. Friedman, *Greedy Function Approximation: A Gradient Boosting Machine* In The Annals of Statistics, 2001, vol. 29, no. 5, pp. 1189–1232

将均值按 $t$ 排列可显示阈值、单调性或饱和。两特征分析可在二维网格重复操作，检查交互；平均之外还应查看个体曲线，以识别方向不同的响应。

示例 15.1的四种组合等概率时，$\mathrm{PD}_1(t) = 3 + 2t$、$\mathrm{PD}_2(t) = 2 + 4t$。这给出平均分数响应，未给出每封邮件的预测，也未使用真实标签检验正确性。参考群体改变可以改变截距；本例没有交互，斜率仍为 2 和 4。

替换可能使输入离开观测支持。若数据恒满足 $x_1 = x_2$，模型 $f(x_1, x_2) = x_1 - x_2$ 在观测上总为零，单独改变 $x_1$ 仍会得到上升曲线。该曲线描述人工组合上的模型响应，不能作为观测人群中的现实效应。

按目标特征条件化其他特征，可减少部分无效组合，同时会把特征关联纳入平均。因而应明确使用边缘还是条件分布，不能仅从同样形状的曲线推断它们解释的是同一作用。

**累积局部效应**（accumulated local effects, ALE）在现有取值附近估计小幅变化，再沿特征累积，以减少远离数据支持的替换。这里限定连续特征的一个有界区间 $I$，并将参考总体限制在其中：$P_{\mathrm{ref}}(X_j \in I) = 1$，$X_j$ 的 Lebesgue 密度在 $I$ 上几乎处处为正。假设模型对第 $j$ 项可微，相应导数在条件分布下可积，条件导数均值在 $I$ 上绝对可积。对 $t_0, t \in I$，一阶表达为

$$\mathrm{ALE}_j(t) = \int_{t_0}^{t} \mathbb{E}_{P_{\mathrm{ref}}}\left[ \frac{\partial f(s, \boldsymbol{X}_{-j})}{\partial s} \,\middle|\, X_j = s \right] \mathrm{d}s - C_j \,, \tag{15.3}$$

$t_0$ 是积分起点，$C_j$ 使结果在同一 $P_{\mathrm{ref}}$ 下中心化。正密度条件使条件均值的版本差异只落在 Lebesgue 零测集上，不改变这里的积分；绝对可积条件也保证累积值与中心化常数有限（可参考第一卷“随机变量”章的“正则条件分布”定义及其版本边界）。实际可将取值分箱，在每箱已有样本上查询边界差并累加平均差，不必计算导数[4]。离散特征或无数据区间需要另行声明差分或外推约定，不能由上述积分自动确定。

PD 平均完整输出，ALE 平均局部变化。ALE 减少部分外推，但粗分箱可能越过无数据区，细分箱又可能缺少样本；模型在数据流形外的延伸仍可能影响局部导数。这些方法未识别现实因果作用。保留个体响应曲线可进一步检查总体均值遗漏的交互。

**任务表现对信息的依赖**　曲线没有利用真实结果，因而不能说明敏感性是否有助于分类。检查模型是否靠页脚正确判断，需要对同一模型比较保留和破坏页脚信息时的损失。这个问题以任务表现为依据，不能由系数大小回答。

**置换重要性**（permutation importance）固定模型，打乱测试样本中某字段并比较损失。应在同一批样本上成对计算，重复置换，报告增量及波动[5,6]。超过预设阈值的损失增量支持该破坏规则下的性能依赖，依赖是否合理或是否具有现实因果意义仍需其他判断。

[4] D. W. Apley, J. Zhu, *Visualizing the Effects of Predictor Variables in Black Box Supervised Learning Models* In Journal of the Royal Statistical Society Series B: Statistical Methodology, 2020, vol. 82, no. 4, pp. 1059–1086

[5] L. Breiman, *Random Forests* In Machine Learning, 2001, vol. 45, no. 1, pp. 5–32

[6] C. Strobl, A.-L. Boulesteix, A. Zeileis, T. Hothorn, *Bias in Random Forest Variable Importance Measures: Illustrations, Sources and a Solution* In BMC Bioinformatics, 2007, vol. 8, pp. 25

设 $\pi$ 为样本索引排列，$\boldsymbol{x}_i^{(j,\pi)}$ 仅将第 $j$ 项替换为 $x_{\pi(i),j}$，一次置换的损失增量是

$$\hat{I}_j^{(\pi)} = \frac{1}{n}\sum_{i=1}^{n}\left[\ell\big(f(\boldsymbol{x}_i^{(j,\pi)}), y_i\big) - \ell\big(f(\boldsymbol{x}_i), y_i\big)\right]. \tag{15.4}$$

$y_i$ 用于比较任务损失，模型全程不重训练。教学测试 100 封邮件，误判由 10 增至 25，增量为 0.15。重复试验反映置换随机性，推广到新邮件总体时还应考虑测试样本不确定性。

页脚与发送方配套时，单独置换会制造无效组合，使损失混入分布外效应。按发送方分组置换研究剩余信息，联合置换研究整组信息。互相替代的字段中，模型未使用的那一项可有零重要性，但仍包含预测信息；删除后重训练则检验学习系统能否利用替代信息，应单独报告。

响应与性能依赖可以不同。分数变化未跨分类阈值时，零一损失增量可能很小；破坏被错误使用的信息甚至会降低损失。曲线描述模型怎样响应，置换损失描述响应对所选指标的后果，任务语义再决定该依赖能否接受。

### 15.2.3 基于语义的解释

输入字段未必对应读者关心的含义。“催促付款”有多种表达，同一词也可能属于引用或警示。语义解释以来源可验证、立即转账等概念组织证据，可以把概念放进实际预测路径，也可以在已有表示中检验概念方向。

Koh 等的**概念瓶颈模型**（concept bottleneck model）先预测人定义的概念，再只通过概念判断结果。语义接口因而进入模型计算，可以查看和修改；它区别于输出后附加概念描述[7]。

设概念 $\boldsymbol{c} \in \mathbb{R}^m$、概念预测器 $g$ 与决策函数 $h$，则 $f(\boldsymbol{x}) = h(g(\boldsymbol{x}))$。有概念标签时，可以先训练 $g$ 再用真实或预测概念训练 $h$，也可以联合任务和概念损失。不同训练方式决定任务信号是否改变概念，以及使用时的概念误差是否与训练一致。人工确认邮件来源后，可替换对应概念并重新检查输出。

整套规则解释仍须说明 $h$ 怎样组合概念，例如给出加性项、阈值或路径。复杂 $h$ 提供可核查接口，却没有自动展开全部计算。要概括概念作用，应在目标任务样本中检验，而非仅展示一次成功纠正。

命名接口仍可能出错：概念误判向下游传播，概念遗漏降低任务能力，连续分数还可能携带名称之外的信息。若存在绕过瓶颈的路径，概念替换也不能控制所有依据。验收应共同核查概念质量、替换效果与任务损失。

**概念激活向量检验**（testing with concept activation vectors, TCAV）在已有表示中提出语义假设。Kim 等用概念与对照样本在某层训练线性分隔器，得到朝目标概念的方向 $\boldsymbol{v}_C$，再统计类别分数沿该方向导数为正的比

[7] P. W. Koh, T. Nguyen, Y. S. Tang, S. Mussmann, E. Pierson, B. Kim, P. Liang, *Concept Bottleneck Models* In Proceedings of the 37th International Conference on Machine Learning, 2020, pp. 5338–5348

例。它把模型对概念的使用问题转为可重复的表示敏感性检验，无须重训概念瓶颈[8]。

若激活为 $\boldsymbol{h}(\boldsymbol{x})$、后续类别分数为 $s_k(\boldsymbol{h})$，被统计的是 $\nabla_{\boldsymbol{h}} s_k(\boldsymbol{h}(\boldsymbol{x}))^{\top} \boldsymbol{v}_C$ 的符号。样本、对照与层都影响结果，应重复拟合并报告不确定性。可分方向可能捕捉共现背景，正导数也只是内部局部敏感性；它既非现实概念干预的概率效果，也未限制模型只能使用所命名概念。

实施时，概念实例与对照用于学习方向，目标任务样本用于测作用，另留样本用于复核。固定模型和层后，记录激活、训练线性分类器、确定正类朝向，再计算各目标样本方向导数。对集合 $\boldsymbol{D}_k$，可汇总为

$$\hat{t}_{C,k} = \frac{1}{|\boldsymbol{D}_k|} \sum_{\boldsymbol{x} \in \boldsymbol{D}_k} \mathbb{I}\{\nabla_{\boldsymbol{h}} s_k(\boldsymbol{h}(\boldsymbol{x}))^{\top} \boldsymbol{v}_C > 0\} .$$

100 个样本中 80 个正导数对应 0.8，表示八成样本有正局部敏感性，不能读为贡献占 80%。更换概念实例和随机对照后，若目标方向持续高于随机方向，并报告差值与不确定性，才加强概念假设的证据。

结构、输入与语义各自解释组合方式、字段作用及对应含义。概念瓶颈改变实际结构，TCAV 检验已有表示，因此同一方法可以连接多个方面。整体结论还须交代样本覆盖、汇总规则及方向相反的子群。

## 15.3 单次行为的解释

单次行为可追溯到输入、运行计算和训练经历。误拦邮件的三个问题分别是哪些内容触发、哪些组件参与处理，以及哪些学习样本使模型形成这种判断。解释范围固定在当前行为，但各方法改变的对象不同。

相似案例、反事实、代理与归因都固定训练结果并分析输入响应。内部解释检查当前计算作用，数据解释则改变学习经历并观察同一输入的结果。以下按论断对象组织方法，输入查询或参数访问只规定获得证据的条件。

解释前应指定输出是垃圾邮件分数、隔离动作还是隔离与复核之间的选择。阈值和权限也参与最终动作，只解释分数可能遗漏它们。下文以 $f(\boldsymbol{x})$ 表示目标标量分数，$\hat{y}(\boldsymbol{x})$ 表示经决策规则得到的类别或动作；多类别时还须固定类别。

### 15.3.1 基于推理输入的解释

输入解释通过检索参照或构造变化，把当前结果与输入差异联系起来。同结果近邻提示共同因素，不同结果近邻提示边界，系统变化则可拟合响应或分配贡献。方法的共同对象是固定模型的输入输出，交付的证据形式不同。

[8] B. Kim, M. Wattenberg, J. Gilmer, C. Cai, J. Wexler, F. Viegas, R. Sayres, *Interpretability Beyond Feature Attribution: Quantitative Testing with Concept Activation Vectors (TCAV)* In Proceedings of the 35th International Conference on Machine Learning, 2018, pp. 2668–2677

输入分析可以检索原有样本，也可以读取导数，不一定实际修改当前邮件。最终类别相同仍可能伴随超过预设幅度的分数变化，因此应记录究竟比较分数、类别还是动作。

**相似案例的对照** 基于案例的解释（example-based explanation）展示与当前输入相似且判断相同的参照。例如，支付要求与可执行附件触发隔离时，可显示同样包含两项因素的已隔离邮件，标记共同片段，让读者了解本次结果所在的案例组。

检索先要定义相似性采用词语、业务字段还是表示，以及可忽略的差异，再在参考库中显示近邻的距离、共同点和区别。有真实标签时应同时展示标签与预测，避免把相似误判当成正确依据。多个近邻或代表性原型可减少偶然选择的影响。

案例对照的证据强度取决于预测机制。近邻或原型模型可以显示实际参与的案例和权重；预测后再检索的案例只提供线索。若声称共同因素解释当前判断，还需改变这些因素并核对输出。

Chen 等的原型部件网络（prototypical part network, ProtoPNet）比较图像局部与学习原型的表示相似度，再加权得到类别分数。原型关联训练片段，可以显示当前区域对应哪个典型部分及其分数作用。这里案例比较属于实际计算路径[9]。

相似性可能来自背景或邮件模板，与读者理解的物体和业务意图不同。应显示实际比较区域与贡献权重，减少读者自行猜测；相近而输出不同的案例还能帮助检查边界。

[9] C. Chen, O. Li, C. Tao, A. J. Barnett, J. Su, C. Rudin, *This Looks Like That: Deep Learning for Interpretable Image Recognition* In Advances in Neural Information Processing Systems, 2019

**不同结果的反事实比较** 反事实比较研究哪些差异能够改变当前判断。可检索真实的不同结果近邻，也可只修改少量条件重新查询。前者提供观察对照，后者通过控制其他因素检验变化作用。

Wachter 等的**反事实解释**（counterfactual explanation）搜索接近当前输入而达到目标输出的候选，可优化距离与目标损失，也可把输出要求列为约束。方法将当前结果转换为明确的替代输入问题[10]。

设不同结果的目标集合为 $Y_{\text{target}}$，距离为 $d$，有效输入集为 $\boldsymbol{X}_{\text{valid}}$，可求

$$\min_{\boldsymbol{x}' \in \boldsymbol{X}_{\text{valid}}} d(\boldsymbol{x}', \boldsymbol{x}), \qquad \hat{y}(\boldsymbol{x}') \in Y_{\text{target}} . \tag{15.5}$$

搜索可从真实近邻、枚举或梯度方法开始，候选必须通过完整预测重新核验并列出改动。尺度、离散取值和有效组合应预先确定，否则最近可能只是单位选择的结果。有限搜索找到候选，也未证明最小性或唯一性。

沿用示例 15.1，当前 $(1,1)$ 得 7 分。将附件改为非可执行、保留支付要求后，$(1,0)$ 得 3 分；去掉支付要求、保留附件后，$(0,1)$ 得 5 分，两者均

[10] S. Wachter, B. Mittelstadt, C. Russell, *Counterfactual Explanations without Opening the Black Box: Automated Decisions and the GDPR* In Harvard Journal of Law & Technology, 2018

越过放行边界。因此，在另项不变时，任一改动都足够。只展示附件方案会遗漏另一条路径。

这些结论以固定模型、参照和允许改动为条件。多字段不同的真实近邻仅提示差异，受控重算进一步检验预测作用。预测变化还不说明现实因果后果或行动可行性；第 15.5节将补上行动条件。

为了单独看清输入距离，图 15.2改用示例 15.3中的连续申请场景。这里 $s$ 为技能分数，$r$ 为当期资源，申请在 $s + r \geq 3$ 时批准。当前 $(1, 1)$ 到批准区域的欧氏最近点为 $(1.5, 1.5)$，这里只比较输入距离，尚未计算培训和支持的后果及成本。

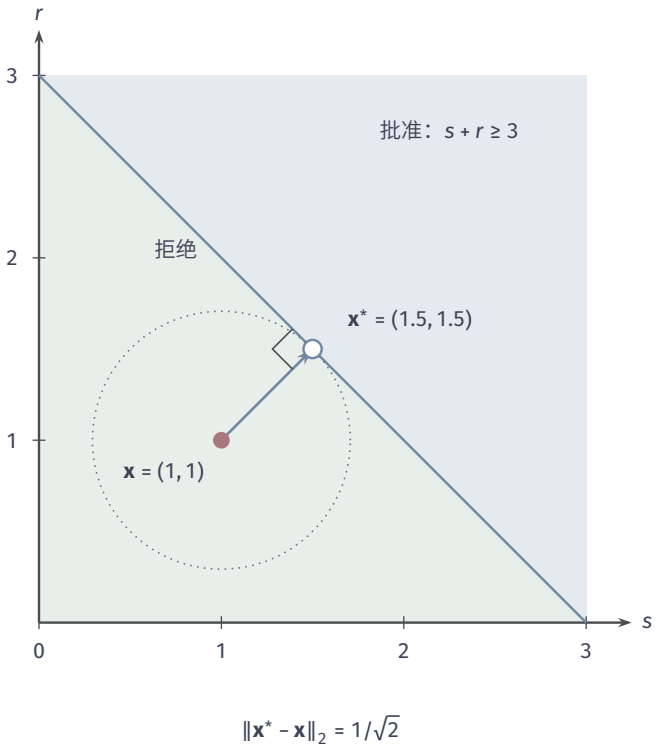


图 15.2 等权欧氏距离下的最近目标输入。从 $(1, 1)$ 到含边界 $s + r = 3$ 的批准区域，垂直投影为唯一最近点 $(1.5, 1.5)$，距离 $1/\sqrt{2}$。虚线圆与直角记号分别显示等距和垂直关系。此处没有行动约束，实际补救路径另见图 15.6。

案例与反事实提供具体参照。若要系统说明当前分数，可拟合附近变化的响应规则，也可分配相对基准的差异。后面的代理、扰动与归因分别采用这些比较，输出数值应按所定义的问题解释。

**附近输入的响应规则** 局部可解释模型无关解释（local interpretable model-agnostic explanations, LIME）在当前输入附近查询模型，按接近程度加权拟合简单代理并惩罚复杂度。采样规则、距离与代理误差共同决定解释范围[11]。

[11] M. T. Ribeiro, S. Singh, C. Guestrin, *"Why Should I Trust You?": Explaining the Predictions of Any Classifier* In arXiv preprint arXiv:1602.04938, 2016

邮件词项保留向量 $\boldsymbol{z}$ 可通过 $r(\boldsymbol{z})$ 映射成可查询文本。设代理族为 $G$，接近权重为 $w_{\boldsymbol{x}}$，复杂度为 $\Omega$，$\lambda \geq 0$，可拟合

$$\hat{g} = \arg\min_{g \in G} \left\{ \sum_{i=1}^{n} w_{\boldsymbol{x}}(\boldsymbol{z}_i) \big[ f(r(\boldsymbol{z}_i)) - g(\boldsymbol{z}_i) \big]^2 + \lambda \Omega(g) \right\}. \tag{15.6}$$

把较大权重集中在较窄邻域，能突出当前输入，却减少可识别的变化；扩大高权重邻域，则可能超出简单模型的拟合能力。删词还可能破坏语法或任务目的，应核查邻域有效性并在另取邻域样本上报告误差。系数回答的是这个加权近似问题。

LIME 的计算先采样可读的删词向量，查询原模型分数，再按距离拟合少量非零系数。解释交付所选词项、系数及邻域误差，原模型参数保持固定。这些对象共同说明代理在哪里、以多大误差近似当前响应。

示例 15.1的加性规则若有足以识别两项作用的邻域样本，无稀疏惩罚的线性拟合可恢复 2 和 4。存在交互时，词项系数可能随邮件改变。整体代理也采用查询后拟合，但其样本与误差覆盖总体，LIME 则集中在当前输入的权重邻域。

邻域代理解释附近输入怎样改变输出，归因则标记当前证据或分配分数差。有的方法仅给出敏感位置，有的要求贡献之和满足规定差值。后一要求依赖基准与组合价值定义，数值应据此解读。

**扰动比较与局部敏感性**　遮挡通过输入输出查询计算单项作用：按规定参照替换第 $j$ 项，比较替换前后分数。文本可替换片段，图像可替换区域。交互与冗余会使各项移除效果不能相加为总差，替换规则也必须列入解释定义。

可微分 $f$ 的梯度描述小幅输入变化的终点敏感性。饱和区的梯度可能很小，但该特征仍参与了较早的分数变化。若要分配相对基准的差异，需要规定路径并累计沿途作用。

**相对于基准的贡献分配**　积分梯度（integrated gradients, IG）选择基准 $\boldsymbol{x}_0$ 并沿直线路径到 $\boldsymbol{x}$ 积分各维导数：

$$\mathrm{IG}_j(\boldsymbol{x}) = (x_j - x_{0,j}) \int_0^1 \frac{\partial f(\boldsymbol{x}_0 + t(\boldsymbol{x} - \boldsymbol{x}_0))}{\partial x_j} \, \mathrm{d}t \,. \tag{15.7}$$

令 $\boldsymbol{\gamma}(t) = \boldsymbol{x}_0 + t(\boldsymbol{x} - \boldsymbol{x}_0)$、$\varphi(t) = f(\boldsymbol{\gamma}(t))$。若 $\varphi$ 在 $[0,1]$ 上绝对连续，各坐标的 $(x_j - x_{0,j})\partial f(\boldsymbol{\gamma}(t))/\partial x_j$ 可积，并几乎处处满足

$$\varphi'(t) = \sum_j \frac{\partial f(\boldsymbol{\gamma}(t))}{\partial x_j} (x_j - x_{0,j}),$$

则积分链式关系与微积分基本定理给出 $\sum_j \mathrm{IG}_j(\boldsymbol{x}) = f(\boldsymbol{x}) - f(\boldsymbol{x}_0)$。整条路径邻域连续可微是更强的充分条件。分段光滑模型也需检查复合函数和几乎处处链式关系；路径落在不可微集合且选用导数不代表路径导数时，不能直接援引完整性等式。

完整性表示相对基准的分数差得到分配，并未赋予基准或路径现实因果含义。Sundararajan 等以归因公理提出该方法，空文本、黑图像或平均输入是否适合仍由任务决定[12]。词嵌入插值未必对应合法句子。有限插值点只近似积分，应报告贡献和的求积残差，不能把数值误差解释成模型遗漏的因素。

[12] M. Sundararajan, A. Taly, Q. Yan, *Axiomatic Attribution for Deep Networks* In Proceedings of the 34th International Conference on Machine Learning, 2017, pp. 3319–3328

数值实现可在多个插值点计算梯度，求平均后乘各维输入差。示例 15.1 的规则从 $(0,0)$ 到 $(1,1)$ 的梯度恒为 $(2,4)$，得到贡献 2 和 4，合计 $7-1=6$。更换基准就更换了待分配差值，因此基准应随结果报告。

图 15.3 把两项输入与可复算贡献对应。条长是固定基准上的分数增量，不能读作现实损害或因果强度。

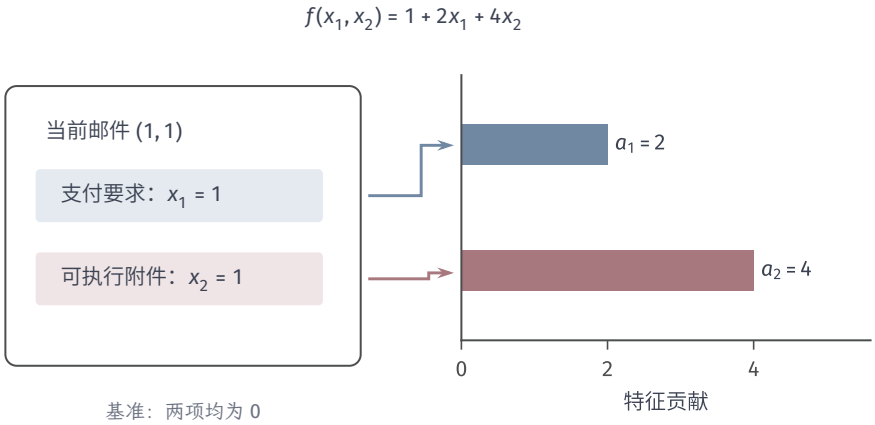


图 15.3 相对 $(0,0)$ 的教学特征贡献。基准 1 与当前 7 相差 6，直线路径梯度恒为 $(2,4)$，因此 IG 贡献为 2 与 4。输入标记对应从零起的贡献条，邮件文字只表示规定的二元特征。归因解释分数差，未给出概率或现实因果结论。

预测解释还可以比较特征组合的输出增量，再平均每项在所有加入次序中的增量，以形成贡献分配。设 $N = \{1, \dots, d\}$，$\mu(S)$ 为按规定的缺失特征填充方式保留当前特征子集 $S$ 时的平均输出，假设各联盟的平均输出均有限。将背景输出 $b = \mu(\varnothing)$ 单列，并令 $v(S) = \mu(S) - b$，于是 $v(\varnothing) = 0$。第 $j$ 项贡献为

$$\phi_j = \sum_{S \subseteq N \setminus \{j\}} \frac{|S|!(d - |S| - 1)!}{d!} \big[ v(S \cup \{j\}) - v(S) \big]. \tag{15.8}$$

SHAP（Shapley additive explanations）利用这种分配形成加性贡献；完整输入的贡献之和为 $f(\boldsymbol{x}) - b$，背景输出 $b$ 另作截距。缺失特征怎样补充、

使用何种分布，决定 $\mu(S)$、基准与所解释问题[13]。（可参考第一卷“多方策略的响应与演化”章的“Shapley 值”定义）。

边缘背景采样给出 $\mu(S) = \mathbb{E}[f(\boldsymbol{x}_S, \boldsymbol{X}_{-S})]$，主要比较人工组合上的响应；$v(S) = \mu(S) - b$ 只扣除同一个背景常数，不改变各项加入时的增量。按已知特征条件采样则保留关联，也可能给未被模型直接读取但预测其他特征的变量分配贡献，仍须按同一背景输出中心化。二者依定义回答不同问题。精确枚举有指数规模，结构方法或采样近似应报告背景与计算误差。

排列解释可从背景起依次加入当前特征，记录每项加入前后的价值增量，再平均所有进入次序；大量特征时近似采样次序。式 (15.8)正是这种平均。它比较特征组合，IG 比较连续路径，二者的共同产物虽是贡献，定义并不相同。

> **示例 15.2　共同信息的贡献分配**　设 $v(\varnothing) = 0$，$v(\{1\}) = v(\{2\}) = v(\{1,2\}) = 1$，任一信息都足够，二者互相替代。每项先进入时增量为 1，后进入时为 0，Shapley 平均得到 1/2。完整输入中删除一项仍保留价值 1，所以分配一半不等于单项移除使输出下降一半。

**支持区域的定位**　图像解释可先定位支持目标类别的区域。梯度加权类激活映射（gradient-weighted class activation mapping, Grad-CAM）平均目标分数对卷积特征图的空间梯度，以此给通道加权，并保留正响应。设通道图为 $\boldsymbol{A}^k$、空间位置数为 $Z$、目标分数为 $s_c$，则

$$\begin{aligned} \alpha_k^c &= \frac{1}{Z} \sum_{i,j} \frac{\partial s_c}{\partial A_{i,j}^k}, \\ L_{i,j}^c &= \max\left(0, \sum_k \alpha_k^c A_{i,j}^k\right). \end{aligned} \tag{15.9}$$

梯度表示通道对当前分数的敏感性，特征图给出空间响应，合成结果是粗粒度位置证据。Selvaraju 等在多种卷积网络中研究了这种类别定位[14]。

Grad-CAM 定位某层表示中支持类别的区域，IG 分配基准分数差。前者受层分辨率、通道梯度平均和正值截断限制，会遗漏反对证据及通道内差异。上采样边缘不能支持像素因果主张，应比较不同类别和对照区域，而非仅凭视觉像物体判断解释质量。

### 15.3.2 基于推理计算过程的解释

输入响应提出哪些信息有关，内部解释则固定参数并检验表示、组件和通路怎样参与计算。能从激活解码信息只说明表示含有该信息；替换、屏蔽或恢复后观察行为，才检查计算作用。内部干预也可能制造异常状态，需设置匹配对照。

[13] S. Lundberg, S.-I. Lee, *A Unified Approach to Interpreting Model Predictions* In arXiv preprint arXiv:1705.07874, 2017

[14] R. R. Selvaraju, M. Cogswell, A. Das, R. Vedantam, D. Parikh, D. Batra, *Grad-CAM: Visual Explanations from Deep Networks via Gradient-based Localization* In Proceedings of the IEEE International Conference on Computer Vision, 2017

一种方法先保存干净运行，再构造使目标行为受损的输入，将某位置的干净激活放入受损运行。恢复输出支持该位置在当前设置中的作用。Meng 等的因果追踪使用此类实验定位事实关联，并以参数编辑继续检验假设；激活可能携带多因素，其他通路也可能冗余保存，局部恢复不能证明唯一存储[15]。

[15] K. Meng, D. Bau, A. Andonian, Y. Belinkov, *Locating and Editing Factual Associations in GPT* In Advances in Neural Information Processing Systems, 2022

实际实验分别记录干净、受损与单位置替换后的分数 $s_{\text{clean}}$、$s_{\text{corrupt}}$ 和 $s_{\text{patch}}$。前者大于受损分数时，可把恢复差相对原差归一化为

$$r_{\text{restore}} = \frac{s_{\text{patch}} - s_{\text{corrupt}}}{s_{\text{clean}} - s_{\text{corrupt}}}, \tag{15.10}$$

教学值 4、0、3 给出 0.75，表示此次替换恢复四分之三分数差，不能解释为知识量。比例可负或超出 1，小分母也会使其不稳。位置恢复图还应在其他输入配对和对照替换中复测。

图 15.4对应三次运行。在同一计算位置复制激活改变受损分支的后续输出，所有运行使用固定参数。

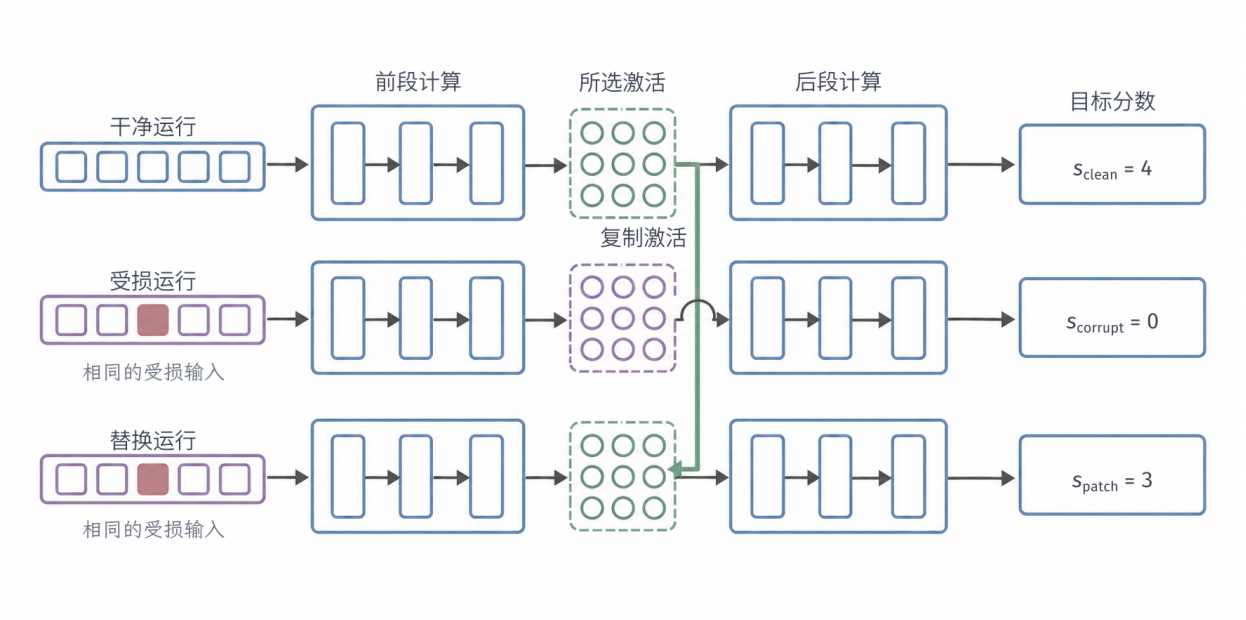


图 15.4 固定参数下的激活恢复试验。第三行保留第二行的受损输入，将干净运行的激活复制到同层同位置后继续前向；教学分数 4、0、3 给出恢复比例 0.75。比例只描述此次分数恢复，不能计量知识或证明唯一位置。绿色复制线与第二行灰色计算线在跨线处不相连。

输入归因分配输入作用，机制干预检查内部计算改变后的行为。两者都可能访问激活或梯度，划分依据是主张对象：Grad-CAM 主要交付区域定位，激活替换交付内部操作的结果。归因提出的机制假设还需要干预检验，不能直接等同于机制结论。

移除组件后行为消失支持当前设置中的必要性，局部恢复则支持特定背景中的恢复作用。输入污染、替换位置与评分目标都限定结论。多配对、等强度随机替换与组合消融可以排除部分替代解释，单次恢复仍不足以重建全部计算。

工具调用与长生成把解释单位扩展为状态和动作序列。先确定最终行为指标，再定位引入证据的步骤，替换或屏蔽该状态后重放后续过程，检查任务结果。序列干预仍以运行条件为范围；最终文本可能隐藏中间动作的错误。

### 15.3.3 基于训练数据的解释

怀疑误拦来自错标训练样本时，需要固定当前邮件，改变训练输入、标签或权重，研究学习后预测的变化。此前的输入和内部解释固定参数，这里则追溯学习怎样产生参数。因此训练样本影响与当前邮件删词效果属于不同实验。

删样本重训练可作直接参照，但成本较高。**影响函数**（influence function）利用局部最优解对样本权重的导数近似变化。为固定归一化尺度，先设无另行缩放正则项的平均目标为

$$\hat{R}(\theta) = \frac{1}{n}\sum_{i=1}^{n} \ell(z_i, \theta), \qquad \boldsymbol{H} = \nabla_\theta^2 \hat{R}(\hat{\theta}),$$

其中 $\hat{\theta}$ 是局部最优解，$\boldsymbol{H}$ 可逆，且各损失在当前解的邻域内二阶连续可微。将目标改为 $\hat{R}(\theta) + \epsilon \ell(z, \theta)$，沿附近平稳点分支 $\hat{\theta}_\epsilon$ 对一阶条件求导，得到

$$\left.\frac{\mathrm{d}\hat{\theta}_\epsilon}{\mathrm{d}\epsilon}\right|_{\epsilon=0} = -\boldsymbol{H}^{-1} \nabla_\theta \ell(z, \hat{\theta}).$$

取 $z = z_i$ 时，按 $n-1$ 归一化的删样本目标与 $\hat{R} - \ell(z, \theta)/n$ 只差正常数倍，具有相同极小点。因此以 $\epsilon = -1/n$ 作一阶外推，有

$$\hat{\theta}_{-z} - \hat{\theta} \approx \frac{1}{n} \boldsymbol{H}^{-1} \nabla_\theta \ell(z, \hat{\theta}).$$

有限外推依赖局部解、光滑性和目标缩放；有正则项时应重推尺度。样本少、单点影响强、解不唯一或训练路径变化都会破坏近似。Koh 与 Liang 研究了该方法的预测追溯应用，实际数据归因还需部分重训练或受控修改复核[16]。

对测试样本 $z_*$ 的损失再作一阶展开，删样本效果为

$$\ell(z_*, \hat{\theta}_{-z}) - \ell(z_*, \hat{\theta}) \approx \frac{1}{n} \nabla_\theta \ell(z_*, \hat{\theta})^\top \boldsymbol{H}^{-1} \nabla_\theta \ell(z, \hat{\theta}).$$

[16] P. W. Koh, P. Liang, *Understanding Black-box Predictions via Influence Functions* In Proceedings of the 34th International Conference on Machine Learning, 2017, pp. 1885–1894

内积取负号对应增加样本权重时的局部变化。这个量由梯度作用定义，不是输入距离：相似邮件可以有不同梯度，不相似错标也可改变边界。大型模型可通过海森向量积近似解线性系统，但计算方式并不消除局部最优前提。

未达到稳定最优时，可用 TracIn 追踪训练更新的作用。单样本梯度下降中，测试损失下降的一阶近似为

$$\ell(z_*, \theta^{(t)}) - \ell(z_*, \theta^{(t+1)}) \approx \eta_t \nabla \ell(z_*, \theta^{(t)})^\top \nabla \ell(z_i, \theta^{(t)}).$$

$\eta_t$ 为学习率，梯度针对参数。Pruthi 等在保存检查点上累积此类内积，估计哪些样本有助于降低或增加损失。它避免最终海森求逆，但依赖检查点、步长、批处理及优化器，也不等同于从头删样本训练的反事实[17]。

[17] G. Pruthi, F. Liu, S. Kale, M. Sundararajan, *Estimating Training Data Influence by Tracing Gradient Descent* In Advances in Neural Information Processing Systems, 2020

## 15.4 解释的质量

理解线索是否支持主张，需要分别检查五个方面：与模型行为的符合程度，数值与行为范围的覆盖，合理重复下的稳定，读者的正确理解，以及实际使用收益。它们对应保真度、完整性与覆盖、稳定性、可理解性和使用有效性，应独立取证，不能无条件合成通用分数。

验收先固定版本、输出、范围、基准或干预、使用者及用途，再预设指标、比较对象、容忍误差、样本和重复范围、不确定性报告及失败处理。不同论断需要不同实验，例如删除曲线不能统一验证整体规则与训练影响。以下检查按解释对象选择，阈值由用途决定。

图 15.5只展示两套教学方案在保真度、覆盖和稳定性上纳入的检查项数。它提示证据缺口；人员理解与使用收益仍需另外检验。

### 15.4.1 保真度

**保真度**（fidelity）度量解释与其声称描述的模型行为是否一致。错误模型也可得到如实解释，因此要与预测正确率分别报告；它也不同于因果图中的 faithfulness 条件。

案例解释先核查距离和输出是否满足检索定义，再确认案例是否参与预测。邻居投票或原型权重可以重算；事后检索若声称共同因素是依据，则需改变因素检验响应。案例相似本身只验证了检索结果。

反事实需要通过完整系统复算目标结果，报告距离、修改数和有效性条件。声称某项不可缺少时，可撤销该项并比较组合；还应寻找其他近似方案以检查选择偏向。现实可执行性属于行动补救检验，预测翻转只回答模型条件。

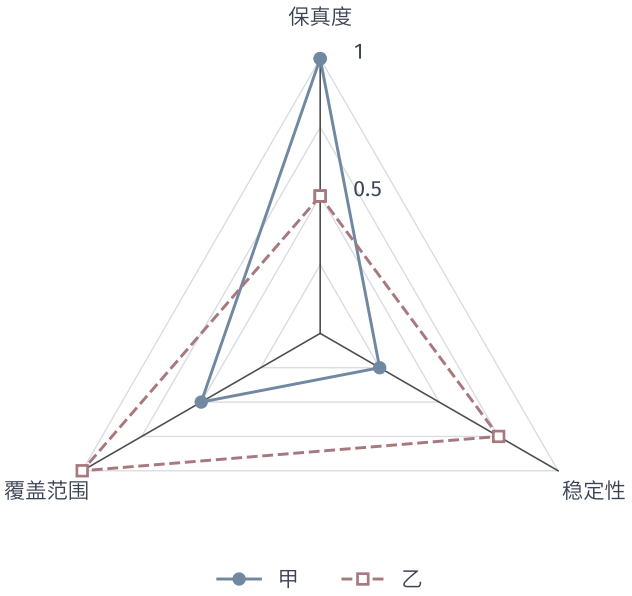


图 15.5 两套构造方案纳入的检查项数。三个维度各预设四项，甲纳入 4、2、1 项，乙纳入 2、4、3 项，径向值为项数除以 4，线型和标记区分方案。真实检查需预先说明内容与难度；图中面积不合成质量评分，另两项人员与使用评价仍须执行。

代理验收在独立查询样本上比较 $f$ 与 $g$。对非负权重 $w_i$，标量分数可采用

$$\widehat{E}_{\mathrm{fid}} = \frac{\sum_i w_i \, [f(\boldsymbol{x}_i) - g(\boldsymbol{x}_i)]^2}{\sum_i w_i}, \qquad \sum_i w_i > 0 \, .$$

整体权重应对应参考范围，局部权重对应邻域。类别复述用一致率，概率复述还需分数误差；应按业务分组检查被均值掩盖的分支。交付容限预先设定，独立样本中报告区间或重采样波动，超限时收窄范围或拒绝交付。

归因定义的一致性与干预预测应分开验收。IG 检查贡献和，SHAP 检查背景与缺失规则；若进一步主张高贡献因素更关键，可按排序逐步删除并与随机、低贡献优先对照，也可从基准逐步插入。曲线和面积支持相应扰动规则下的效果，分配公理不保证在所有删除规则下最优。

扰动实验应匹配改动量与替换方式，并检查输入有效性。删词改变语义、遮挡产生异常块都可能混淆结果。支持与反对证据需分别检查，移除负证据后分数提高有时正符合归因。整体曲线和概念摘要则可在新参考样本上复算，检验重要差异是否复现。

Adebayo 等用参数随机化与标签打乱训练检验显著性图是否依赖学得机制。若预测机制改变后，按预设差异指标解释仍未达到最低变化要求，图可能主要反映边缘或架构先验。这个结果应限定在被测方法与设置，不能泛化为所有显著性方法无效[18]。

[18] J. Adebayo, J. Gilmer, M. Muelly, I. Goodfellow, M. Hardt, B. Kim, *Sanity Checks for Saliency Maps* In arXiv preprint arXiv:1810.03292, 2018

随机化只排除一类缺陷。机制解释应预测新配对中的内部屏蔽或恢复效果，并使用随机位置和等强度替换；训练影响则应对高、低和随机影响样本重新加权或部分重训，核对方向及大小。检验改变的对象应与解释主张相同。

模型理由也是待验收输出，流畅叙述可能来自事后构造。关键证据改变后行为变化而理由未变，会削弱理由解释当前依据的主张。因此需要连接理由与行为试验，语言清晰度只能验证其表达。

### 15.4.2 完整性与覆盖范围

完整性既可指分数差分配，也可指行为范围覆盖。具有加性要求的归因可算

$$e_{\text{sum}} = \left| f(\boldsymbol{x}) - f(\boldsymbol{x}_0) - \sum_j a_j \right| ,$$

$a_j$ 为归因, IG 用残差检查求积, Shapley 需改用所定义 $v(\varnothing)$ 与 $v(N)$。Grad-CAM 没有相同求和承诺。零残差证明约定数值被分完，仍未覆盖全部内部通路或现实原因。

规则和代理应按语言、任务及重要错误预先分组，报告样本量、误差和能够解释的比例。有弃权时同时报告已解释样本质量与总体覆盖，避免只解释简单样本。公式能在未测区域运行，并不构成该区域的解释证据。

机制覆盖需要在多输入、表达与组合中复测局部假设，量化剩余效应。单位置恢复支持当前实验，扩大为一类行为结论时还要承担新范围的证据要求。

### 15.4.3 解释的稳定性

稳定性先固定哪些条件应保持，再比较结论是否超过预设波动容限。固定模型、输入、基准与定义，重复邻域、背景和概念方向采样可测算法随机性。归因可报均值和标准差，排序可报秩相关，前 $k$ 项可报交并比；可交换编号或方向应先匹配。

任务规定的等价变换提供另一类测试。平移区域须映回坐标，改写词项须匹配单位；输出不变时模型仍可能改变依据，因此要结合响应分析解释差异。越过边界后的解释变化可能忠实。计算重复、输入迁移和重新训练后的复现应分别报告。

解释也要对应该改变的条件作出反应。随机化模型后不变可能是无关性，不能视为稳定优势；声称仅解释函数的方法，对实现同一函数的系统应给出相容结论。预先规定保持项与变化项，才能排除恒定输出图的伪稳定。

### 15.4.4 可理解性

可理解性以目标读者是否正确理解为依据。规则数、深度、非零项和概念熟悉度只是负担代理，短而含糊的规则未必比明确计算更容易理解。

人员实验可要求读者根据解释预测新输入的模型反应、比较条件变化或指出适用范围，记录正确率、时间及误解，并匹配难度、事实与背景。在示例 15.1的规则中判断 $(0,1)$ 是否隔离，可检查加性计算与阈值理解；主观清楚评分不能替代这种检验。

Doshi-Velez 与 Kim 区分实际应用人员评价、简化任务人员评价和无人参与的替代指标。规则少和归因稀疏便于测量，是否对应实际理解仍需人员任务的证据[19]。

[19] F. Doshi-Velez, B. Kim, *Towards A Rigorous Science of Interpretable Machine Learning* In arXiv preprint arXiv:1702.08608, 2017

让人预测模型是否拦截，检验对模型的理解；让人判断邮件应否拦截，则同时涉及任务判断能力。实际纠错和错误采纳在下一节评价。喜欢程度只反映主观感受，三者应使用不同观察。

解释组与对照组应获得相同必要事实，否则收益可能来自附加信息。可以保持事实不变只改变组织，或另做附加事实对照。开发者与收件人的背景和任务不同，合适的解释粒度应分别验证。

### 15.4.5 使用有效性

使用有效性检验解释是否帮助发现错误、减少错误采纳或选择复核，并考虑时间和认知成本。理解模型只是前提，实际结果仍须在接近真实的决策任务中评价；补救执行效果另见第 15.5.3节。

可比较无解释、所提解释与等信息量说明，匹配任务难度并记录最终损失、纠错、错误否决和用时。题目随机分配或顺序平衡减少记忆影响。模型错误建议的采纳率应单列，整体采纳增加也可能来自过度信任。

教学例中，两组各处理 100 封匹配邮件，模型均错 20 次。解释组纠正 15 次却新增 8 错，对照组纠正 10 次但只新增 1 错，最终分别为 $20-15+8=13$ 与 $20-10+1=11$。纠错更多并未使最终错误更少；实际比较还需足够样本估计差异不确定性。

保真、覆盖、稳定、理解与收益构成不同证据链，前项成立不自动推出后项。简化导致的取舍应指出具体维度和输入范围。交付解释还应明确接收者与需要完成的判断或行动。

## 15.5 行动补救

误拦解释之后，使用者还需要可执行恢复路径。“不同结果的反事实比较”段找到了改变判断的输入，尚未说明如何实现。**行动补救**（algorithmic

recourse）寻找在权限与现实后果约束下能够达到目标的行动；这里进一步考察权限、流程负担、公平与现实验证（可参考第一卷“因果响应”章的“目标约束下的行动补救”小节）。

补救依次确定行动和目标、在约束中比较方案、核验执行与结果。行动后果决定是否有解，成本决定如何选择，现实验证决定模型中的可行结论能否落实。以下沿同一方案展开这三个环节。

### 15.5.1 补救行动的确定

行动范围先由执行者权限确定。发送方可纠正来源记录、补充证明或转换附件，收件人可能只可请求复核，运营方可修正提取错误或调整流程。一方可做的操作不能直接推荐给另一方。

候选路径可从记录纠错、现实条件改变和流程申诉中获得。前两类通常经新输入重新判断，后一类还改变决策流程，应说明处理者、依据与时限。进入人工复核也不是简单降低模型分数。

补救目标应包含真实任务。删除付款要求可能使邮件放行，却也删掉业务请求；目标因此应同时检查恰当处理与内容保留。若期望复核，应检验是否进入并完成流程，而不是强求立即有利分类。

候选行动须列出执行者、对象、资源、时长和预期变化。例如，由发送方把附件转换成保留必要信息且无可执行内容的格式再提交，才构成可实施方案。解释产生线索，领域知识与权限决定线索能否执行。

设当前状态为 $\boldsymbol{x}$，行动后果为 $T(\boldsymbol{x}, a)$，它描述字段及其他状态随 $a$ 怎样变化。固定决策时结果为 $\hat{y}(T(\boldsymbol{x}, a))$；流程复核则需另定义结果。小输入距离不代表低行动成本，记录改写也未必改变相应事实。

### 15.5.2 补救行动的选择

行动集合由不可变属性、权限、方向和取值限定，后果又受预算、截止时间与业务内容限制。合同信息必须保留等条件应作为硬约束；可行方案之间的时间或费用偏好进入目标。筛选与排序分别承担这两种作用。

令允许行动集为 $A(\boldsymbol{x})$、成本为 $c(a;\boldsymbol{x})$、目标输出集为 $Y_{\text{goal}}$。固定规则下的低成本方案可求

$$\begin{aligned} &\min_{a \in A(\boldsymbol{x})} \quad c(a;\boldsymbol{x}) \\ &\text{满足} \quad \hat{y}(T(\boldsymbol{x}, a)) \in Y_{\text{goal}}\,. \end{aligned} \tag{15.11}$$

$A$ 规定允许行动，$T$ 计算后果，输出约束检验达标，$c$ 比较达标方案。目标约束下存在可行行动才有补救，最优性则还依赖所声明范围、后果和成本，不能脱离这些条件推广。

成本要对应实际负担。时间、费用和次数可以分列，合成时需解释权重。一个方案各项成本不高于另一个且至少一项更低时，前者支配后者；存在不同偏好时可提供不被支配方案供选择。资源约束变化也可能改变最优方案。

Ustun 等将可行动变量、变化方向、离散值和成本写入线性分类器的整数规划，搜索达到目标的行动，并分析哪些个体缺少方案。这使输入翻转落实为明确的行动约束问题[20]。

[20] B. Ustun, A. Spangher, Y. Liu, *Actionable Recourse in Linear Classification* In Proceedings of the Conference on Fairness, Accountability, and Transparency, 2019

少量候选可枚举后果与成本，连续离散混合行动可在适用模型下规划或搜索。发现可行解证明存在，有限搜索失败不证明无解；全局最优需要完备搜索或有效最优性界，否则应声明当前搜索范围。

行动后果往往相互依赖。培训提升技能也占用时间，可能降低当期资源，不能在输入表中独立设定。Karimi 等利用结构因果模型计算干预沿后继变量的影响，再在行动空间优化成本[21]。

[21] A.-H. Karimi, B. Schölkopf, I. Valera, *Algorithmic Recourse: from Counterfactual Explanations to Interventions* In Proceedings of the 2021 ACM Conference on Fairness, Accountability, and Transparency, 2021

**示例 15.3　约束与成本决定补救方案**　教学申请规则在 $s + r \geq 3$ 时批准，$s$ 为技能分数、$r$ 为当期资源，当前 $(1,1)$ 被拒。直接把技能记录改为 2 可以翻转模型，但培训 $a \geq 0$ 实际造成 $s' = 1+a$、$r' = 1-a/2$，总分为 $2 + a/2$，需 $a \geq 2$。如果培训上限为 1，仅培训就无法达标。

在上述培训上限为 1 的条件下，再允许资源支持 $0 \leq b \leq 1$，令 $r' = 1-a/2+b$，组合成本为 $c(a,b) = a+3b$。目标要求 $a/2+b \geq 1$；单独支持 $(0,1)$ 成本 3，组合 $(1,1/2)$ 成本 2.5，二者均达标。

在这些条件下，可行解满足 $b \geq 1 - a/2$，所以 $c \geq 3 - a/2 \geq 2.5$，组合 $(1,1/2)$ 达到下界而最优。预算改为 2 时，所有允许组合的最低成本仍高于预算，因而无解。这个无解结论来自后果方程和成本下界，而非搜索失败。

图 15.6比较记录改动与行动路径。行动可行性同时依赖权限、后果与预算，模型翻转只是其中一项条件。

后果或未来模型不确定时，可要求候选在一组有依据情形中均达标，或在明确概率模型中达到预设成功率。容限取自任务风险，要求收紧可能增加成本或导致无解。无解应定位预算、权限、后果或规则的限制，再考虑复核及流程调整。

模型内可算还不同于证据可识别。多套结构模型可能符合相同观察甚至边缘干预资料，却预测不同个体后果。应先声明证据与领域假设允许的模型类，再报告方案、成本与成功概率对模型的敏感性，必要时施加类上的稳健约束。缺失识别依据不能仅当参数误差处理（可参考第一卷“因果响应”章的“事实条件下的反事实计算”小节及其中的跨世界识别边界）。

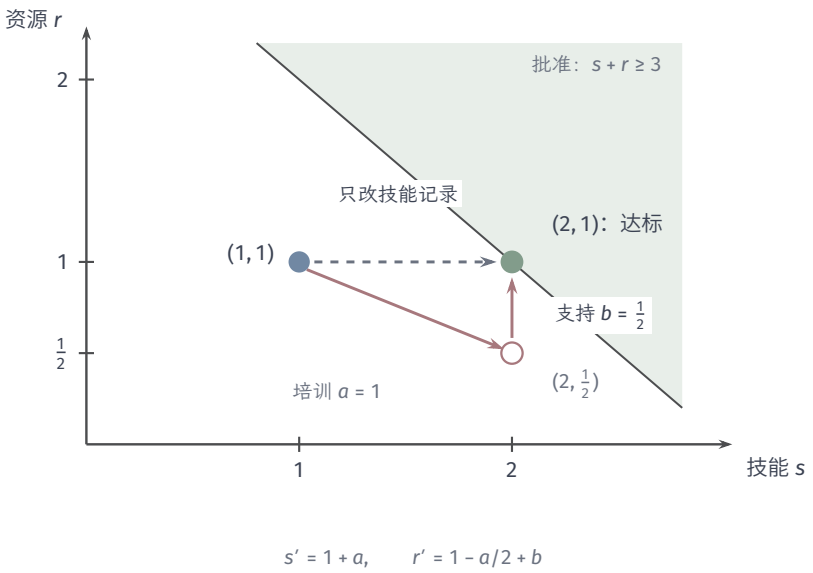


图 15.6 示例 15.3的约束补救组合。虚线表示只改技能记录；培训 $a = 1$ 实际先到 $(2, 1/2)$，支持 $b = 1/2$ 再到批准边界。仅培训且上限为 1 无法达标，组合成本 2.5；预算为 2 时，成本下界证明允许集合中无可行方案。

### 15.5.3 补救效果的验证

补救验收分为计算与执行两层：前者核对约束和目标，后者比较真实后果。第 15.4.5节检查解释怎样影响人的判断，这里检查行动实施后的结果，满意度不能同时替代两种证据。

**方案与约束的复核** 对方案重查权限、不可变属性、取值、时限与预算，再由 $T$ 产生状态，通过实际特征处理和决策重算。代理或连续近似得出的候选须回到真实系统验证。成本最优性可用穷举、精确小问题或有效求解界复核，无法证明时另报限制。

在示例 15.3中，代入教学组合 $(1, 1/2)$ 得到 $(s', r') = (2, 1)$、总分 3、成本 2.5，并满足行动上限，证明模型内可行达标；成本下界另证最优。若预算为 2，该达标候选仍不可执行。

**行动后果与实际收益的检验** 实际记录应包含行动完成、费用、状态变化与最终目标。将新状态与 $T$ 预测对照，才能发现后果高估。技能与资源的观察相关通常不足以预测个人培训效果，可结合干预证据、对照研究与执行记录检验假设，并限定支持范围。

若实际培训每单位消耗资源 0.8，组合 $(1, 1/2)$ 后状态为 $(2, 0.7)$，总分 2.7 而未达标。计算仍符合所设模型，失效来自后果假设。修订应重估后果并重新求方案，不能引用原最优性证明现实有效。

方法评价应分别报告建议可行、实际完成和完成后达标的比例，以及费用和不利后果，并明确每项分母。仅统计执行成功者会遗漏无方案与无法执行者。按群体报告无解、完成、成功、等待和成本分布，可检查不可接受属性路径及申诉负担；个体可行性与制度公平不同，口径见第 13章。声称建议产生收益时，还需与无建议或既有方式对照，处理自选择差异。

验收还应核对业务目标。邮件放行但合同损坏、评分下降但实际风险仍在，都未完成补救。复核与申诉要观察实质处理、错误纠正和时间负担，分别报告决策变化与真实收益。

**效果保持与失效处理** 行动需要时间，因此应标明模型版本、后果假设和有效条件。周期较长时，更新或环境变化可能使方案失效，可在有依据的情形中重算或跟踪实施结果；有限情形不能保证所有未来条件。

无法完成操作时修订行动集，实际后果不符时修订 $T$，规则或流程变化时重查目标。候选、约束优化和验证据此形成修订循环。仍无可行方案的个体，应得到明确限制和可用复核途径。

## 15.6 本章小结

章首三个问题对应不同解释范围。整体规则描述一组邮件的判断，单次证据定位当前拦截；结构、输入和语义分别交代计算组合、具体因素作用及对应含义。结合使用时仍需明确每项主张的范围。

单次解释可以围绕输入响应、内部计算或学习经历取证。案例、反事实、代理和归因固定模型，内部干预改变运行，训练追溯改变学习。贡献可复算不等于机制已确定，内部通路也不等于现实因果；把局部结果汇总为整体结论，还须检验异质性与覆盖。

解释的五类质量分别对应模型、范围、重复、读者和使用任务。补救还需行动权限、后果模型及识别依据，并核查群体机会和成本。清晰解释仍可能如实揭示错误或不公平依赖；展示训练经验和私人特征也会引入披露问题。下一章据此讨论数据、模型发布和信息公开中的隐私保护。

**延伸阅读** Doshi-Velez 与 Kim 的框架可用于区分人员实验和替代指标；LIME 与积分梯度则适合比较邻域代理和基准贡献所支持的不同主张。阅读时沿评价对象与证据条件分析，而非仅比较可视化外观[22,23,24]。

[22] F. Doshi-Velez, B. Kim, *Towards A Rigorous Science of Interpretable Machine Learning* In arXiv preprint arXiv:1702.08608, 2017

[23] M. T. Ribeiro, S. Singh, C. Guestrin, *"Why Should I Trust You?": Explaining the Predictions of Any Classifier* In arXiv preprint arXiv:1602.04938, 2016

[24] M. Sundararajan, A. Taly, Q. Yan, *Axiomatic Attribution for Deep Networks* In Proceedings of the 34th International Conference on Machine Learning, 2017, pp. 3319–3328

反事实解释与因果补救可对照阅读。Wachter 等搜索邻近目标输入，Karimi 等加入行动及连带后果；两条路线分别验证预测条件与行动方案，其差别来自待优化对象[25,26]。

[25] S. Wachter, B. Mittelstadt, C. Russell, *Counterfactual Explanations without Opening the Black Box: Automated Decisions and the GDPR* In Harvard Journal of Law & Technology, 2018

[26] A.-H. Karimi, B. Schölkopf, I. Valera, *Algorithmic Recourse: from Counterfactual Explanations to Interventions* In Proceedings of the 2021 ACM Conference on Fairness, Accountability, and Transparency, 2021

第 16 章

# 隐私保护

一封私人邮件既能帮助训练分类器，也可能带来额外的信息暴露。开发者为检验群体公平性而收集的属性，同样需要保护。即使不公开原始邮件，发布后的参数和回答仍可能泄露训练信息；用户后来撤回邮件，清除文件也不能自动清除模型已经学到的影响。

这类要求在第 10章的三层架构中主要属于系统属性或规范要求：先规定哪些人的哪些信息可以由谁访问、使用或获知。证据能力层用泄露审计、形式化分析和实现核查判断承诺是否成立。失效、处置与生命周期层则负责执行授权和数据流边界，累计重复发布的隐私消耗，并处理数据撤回。

本章先确定保护对象、私人事实和观察渠道，再讨论怎样用结果检验与过程核查验证保护。实现部分依次考察采集、训练和发布使用中的措施，撤回部分分别处置数据副本与模型影响。公平审计贯穿这些问题：细分群体有助于发现集中的伤害，也可能暴露人数很少的成员。因此，方案既要保留判断公平性所需的证据，也要控制这些证据向谁开放；统计更细或数据更少，都不能单独解决这个取舍。

## 16.1 隐私保护的基本概念

### 16.1.1 保护对象与保护范围

用户将邮件交给分类器时，系统获得的可能不仅是该用户的信息，还包括发送者、收件人及其他联系人。提交者可以使用接口，不代表这些第三方的信息可以任意公开。机器学习中的**隐私保护**（privacy protection）据此研究：完成任务的同时，怎样限制个人信息受到不适当的访问、使用、推断和披露。保护需要覆盖训练数据提供者、当前请求的使用者，以及内容中涉及的第三方。

先区分希望保密的事实与机制所保护的单位。前者称为“秘密”，可以是邮件是否参加训练、其中的私人编号，或本次请求携带的地址。后者说明一次比较允许改变哪些数据，例如一条记录，或一个用户的全部记录。秘密确定要阻止观察者获知什么，保护单位确定要限制谁的数据对发布结

果造成的影响。两者回答不同问题：一封邮件得到某种保护，不能据此认定同一用户的一万封邮件仍有相同强度的保证。

第 13章以群体比较预测误差，这里以记录或用户规定保护单位。按群体报告效用损失，并未证明该群体作为整体也具有相同参数的隐私保证。还须说明同一人的记录怎样归集、共同记录中的其他人是否纳入保护；账户归属本身不足以确定全部保护对象。

后文固定一个受控邮件例子。邮件 $z$ 含私人项目编号，训练数据 $D$ 包含该邮件，分类器训练后开放查询。我们分别检查查询者能否识别 $z$ 的训练成员身份、输出能否复现编号，以及训练服务器能否利用共享更新恢复内容。若用户撤回的是全部邮件，处置范围就应包括可定位的所有相关记录与衍生状态，而不止 $z$ 这一条。

可核查的保护承诺要列明人、私人事实、使用目的、允许接收者和系统接口。例如，模型可以为收件人整理邮件，并不由此获得向无关工具传送地址的权限。判断隐私保护时应逐项核对这些范围，训练数据曾否公开只是其中的一项背景。

### 16.1.2 机器学习中的泄露途径

沿着这封邮件的数据流可以找到多种暴露位置。原文可能在采集、传输或存储时被读取；梯度、检查点和调试日志可能在训练时透露样本；发布的参数与查询回答可能保留训练信息。推理中另行提供的私人上下文，还可能进入检索结果、工具调用、回复和服务日志。因此，每个位置都要说明观察者能看到什么，最终回答只是其中一个接口。

泄露审计按希望获知的信息选择方法。**成员推断**（membership inference）判断记录是否参加训练，属性推断（attribute inference）预测未公开字段，数据重构（data reconstruction）恢复输入，训练数据提取（training data extraction）则可通过反复查询诱导训练片段复现。这些方法也可能共享渠道：训练更新可用于重构，发布模型既可用于判别成员，也可用于提取内容。它们按秘密或恢复方式命名，并非把处理过程划成互斥阶段。

泄露并不要求模型逐字保存原文。训练成员与非成员的分数分布有差别，就可能成为身份线索；参数也可能保留共同训练中出现的罕见片段。预测正确则不能反向证明记忆：邮件类别可能由一般语言规律判断出来。审计应比较观察者原有知识、公开规律，以及使用私人数据后额外获得的信息，才能确定这条线索意味着什么。

记录留在本地，只能阻止原文沿某条路径直接传输。若上传的梯度允许重构，或发布模型保留私人片段，其他路径仍会暴露信息。把原文表示为向量、梯度或统计量，也不能单凭表示变化证明保密。检查应分别覆盖原始访问权限、中间计算状态和最终输出的信息。

当前请求也可能在没有训练记忆的情况下泄露。模型将用户刚提交的私人编号发给无权接收的工具，已经越过信息边界，无需此前用它训练。公开网页上的内容同样要结合使用情境判断能否再次披露。用途和接收范围由第 10.1节的情境规定，不能仅从内容来源推断。

### 16.1.3 保护承诺与强度

明文访问与发布结果需要两类限制。访问规则规定谁可读取和操作，协作计算规则规定参与者可见哪些中间状态；二者都未必控制获准取得的统计量或模型透露了多少私人信息。差分隐私进一步限制受保护数据如何改变发布分布，用于补足这一项承诺。访问和用途限制仍须另行执行。

计数例子可以说明这个缺口。查询者已知除 $z$ 以外的全部邮件，服务公布含某关键词的准确邮件数；若 $z$ 含该词，加入它就使计数由 $c$ 增为 $c+1$。查询者于是能确定 $z$ 是否存在。授权查询或将答案称作统计量，都没有减弱这一确定性的区分。

要使参与情况难以由发布值确定，可以限制一个受保护对象对输出分布的影响。比较“包含该对象”与“不包含该对象”时，同一输出事件的概率不能变化过大。**差分隐私**（differential privacy, DP）用相邻数据集将这种要求写成统一的不等式。

先按受保护单位约定相邻关系 $D \sim D'$。随机发布算法 $M$ 具有 $(\epsilon, \delta)$ 差分隐私，须对每一对 $D \sim D'$ 和每个可测输出事件 $E$ 满足 $\mathbb{P}(M(D) \in E) \le e^{\epsilon}\mathbb{P}(M(D') \in E) + \delta$，其中 $\epsilon \ge 0$、$\delta \in [0, 1)$。比较时固定数据集，概率来自算法随机性。相邻关系决定保护谁，输出事件决定观察者能够区分什么（可参考第一卷“数学基础与后续研究”章的“训练模型发布与遗忘输出的可区分性”一节）。

在准确计数中取包含 $z$ 的 $D$、不含 $z$ 的 $D'$ 和事件 $E = \{c+1\}$，这项概率限制的左侧为 1，右侧只有 $\delta$，所以任何 $\delta < 1$ 都不能满足定义。随机化发布值可使两种数据产生足够重叠的输出。定义规定概率变化的限度，机制选择怎样达到它，验证再检查机制与实现；定义本身并未限定一种加噪算法。

相邻关系同时规定保护单位。记录级比较可采用增加、删除一条记录或替换一条记录；用户级比较则改变一个用户的全部记录。在相同约定下，减小 $\epsilon$ 和 $\delta$ 会加强限制。不过，不能把 $\delta$ 简单读成每名用户以该概率被完全公开。

DP 限制的是使用受保护数据所增加的信息，人口层面的公开规律仍可用于推断。即使完全没有读取某人的数据，观察者也可能依据同类人群的共同属性作出判断。DP 也没有保证预测正确，因此需要连同保护定义、实现机制和组合分析理解其结论[1]。

[1] C. Dwork, A. Roth, *The Algorithmic Foundations of Differential Privacy* In Foundations and Trends in Theoretical Computer Science, 2014, vol. 9, no. 3–4, pp. 211–407

可把这项限制改写为固定数据对上的假设检验。设 $D$ 比 $D'$ 多一条待检记录，观察者把输出落入 $E$ 判为“参加训练”。真阳性率为 $t = \mathbb{P}(M(D) \in E)$，假阳性率为 $f = \mathbb{P}(M(D') \in E)$。纯隐私即 $\delta = 0$ 时有 $t \le e^{\epsilon} f$，近似隐私则有 $t \le e^{\epsilon} f + \delta$。定义由此限制所有这样的检验边界，而非只约束某个已知攻击的平均准确率；相邻关系对称，交换两数据后的比较也必须满足。

一次改变多条记录，不能直接套用原记录级参数。对相差 $k$ 条记录的 $D, D'$ 插入 $k-1$ 个中间数据集，沿相邻关系逐步使用定义，得到

$$\mathbb{P}(M(D) \in E) \le e^{k\epsilon} \mathbb{P}(M(D') \in E) + \delta \sum_{j=0}^{k-1} e^{j\epsilon}. \tag{16.1}$$

这给出了群体变化的界，同时显示参数怎样退化。一名用户若最多提交一百封邮件，用户参与可能对应至多一百步相邻变化，不能仍把原记录级 $\epsilon$ 作为用户级 $\epsilon$。按用户限制总贡献或裁剪，会改变要分析的敏感度。

**观察者与信任边界** 中心化 DP 允许可信管理者先接触明文，再发布受保护结果。若这项信任不成立，用户可以在发送前随机化自身信息，形成**本地差分隐私**（local differential privacy）。本地随机化器 $R$ 要对任意输入 $x, x'$ 和任意可测消息事件 $E$ 满足

$$\mathbb{P}(R(x) \in E) \le e^{\epsilon} \mathbb{P}(R(x') \in E) + \delta.$$

保护发生在数据离开用户之前；统计估计也必须承担用户独立随机化所带来的噪声。两种安排区分的是明文可由谁接触，各自仍可用 DP 约束相应接口的输出影响。第 16.3.1节将给出本地发送的具体机制。

## 16.2 隐私保护的验证

验证这封邮件是否泄露，可以从可见输出发起检验，也可以沿处理过程查找违反承诺的位置。输出包括回复、分数、参数和共享更新；观察者在指定权限下尝试恢复私人事实。过程核查则检查数据流、授权、随机机制和发布步骤。前者能发现已利用的泄露，后者能发现尚未被攻击利用的缺口；要证明形式化保证，还须论证全部允许输入。以下先区分两类证据，再判断各自能够支持多强的结论。

### 16.2.1 基于可见结果的泄露检验

经验审计让属性推断、成员推断、内容提取或输入重构尝试利用指定接口。攻击者知识、查询预算、先验和评价数据须预先固定，结果才可同随机猜测和公开规律比较。尤其要控制候选来源：成员与非成员若来自不同时间或数据源，攻击可能识别的是来源差异，不能直接归因为训练参与。

秘密与接口共同决定审计问题。未公开属性需要比较额外推断能力，训练参与需要判别成员，发布模型中的私人片段需要提取测试，共享更新则需要输入重构测试。每项结果都应同时报告恢复了什么、需要何种权限、误报多少以及查询成本，才有可解释的攻击成功率。

**原文与字段的直接暴露** 先检查无需推断的直接交付，例如公开日志写出地址，或工具请求带上不必要的私人编号。隔离测试可插入合成私人标记，保存输入、回复、工具参数和可访问日志，追踪标记到达的接收者。测试须覆盖不同账户权限和处理分支，并预定允许的数据流。标记越界即可确认该路径泄露；未发现标记，只能支持已查路径的结论。随后再用攻击检验没有直接给出原文时是否仍能恢复秘密。

**未公开属性的推断** 对于未公开字段，关键比较是读取模型输出之后是否比原有知识更容易推断。例如，观察者已知邮件主题和发送时间，希望判断私人项目类别；基线攻击器仅用这些已知量，另一攻击器再加入模型分数或表示，两者在同源独立样本上评价。属性目标、先验、可见接口和查询预算应一致，否则准确率上升可能只是多数类别带来的优势。

这项比较支持的是接口新增推断能力的证据。人口相关规律可能让未参加训练的个人也被推断；没有超越基线，则只说明当前知识和预算尚未发现额外信息。报告除基线和总体准确率外，还应给出各属性取值、各群体的错误率，攻击器赋给真实属性值的预测概率，以及预测概率的校准误差。由一个平均数不能直接宣称属性已经泄露或得到保护，DP 也不会消除公开规律产生的推断。

**训练成员身份的判别** 训练样本损失较低可以成为成员线索，但样本本身难度不同，统一置信度阈值未必能将成员充分区分。Shokri 等用成员身份已知的辅助数据训练影子模型，模拟目标训练过程，再学习成员与非成员的输出模式。攻击者据此即使只能查询，也可能获得成员证据，并不需要读到目标训练集[2]。

受控且有授权的审计可以分四步执行：

1. 在同一来源准备候选，记录实际进入目标训练集的样本；攻击器训练数据与最终审计数据分别保存。
2. 用辅助数据训练影子模型，取得已知成员和非成员的损失、预测概率等特征，再以成员标记训练攻击器。
3. 从目标接口取得同类特征，在验证数据上选择阈值，到独立审计集分别计算成员命中率与非成员误报率。

[2] R. Shokri, M. Stronati, C. Song, V. Shmatikov, *Membership Inference Attacks against Machine Learning Models* In 2017 IEEE Symposium on Security and Privacy, 2017

4. 固定查询预算，与不读取目标输出的基准比较，并报告低假阳性区域、实际成员先验及敏感子群结果。

这样得到可检验的身份判定；单条记录的高置信度仍不能单独证明训练记忆。

图 16.1沿候选记录、查询特征、成员判定展示审计。目标成员真值仅供受控核验；辅助数据让攻击器学习输出规律，并不会把目标成员名单交给它。

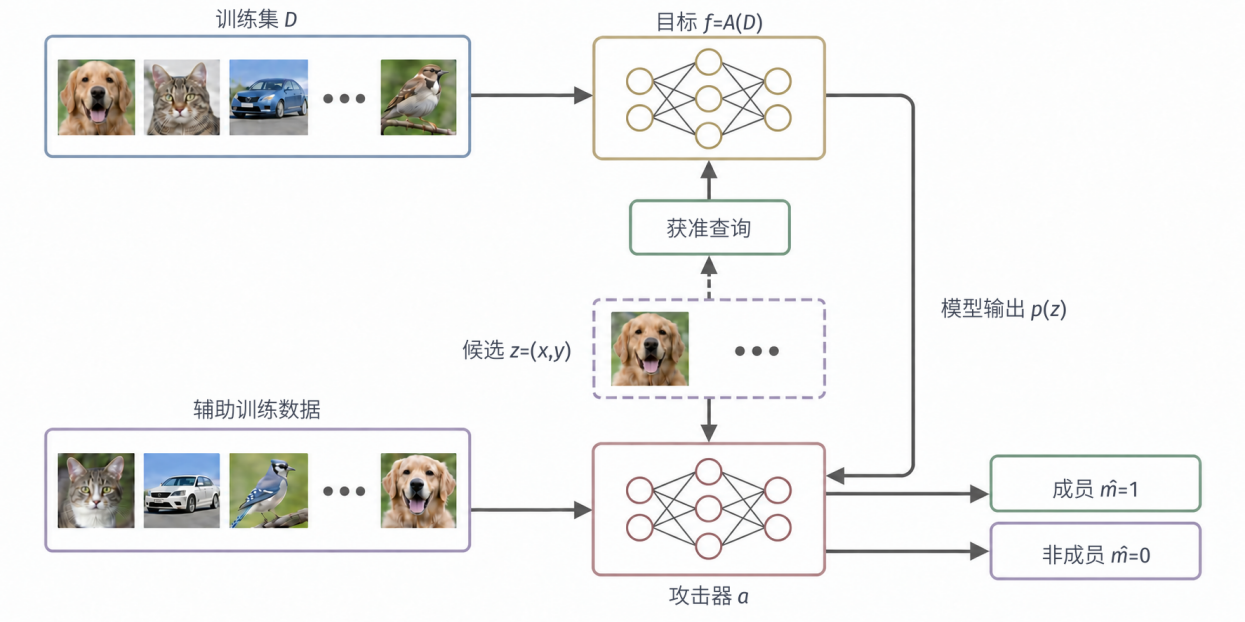


图 16.1 成员推断的受控审计流程。候选成员与非成员按同一分布抽取，目标模型仅用 $D$ 训练；记录 $z=(\boldsymbol{x},y)$ 经获准查询取得输出。图标个数表示分组，不表示成员先验；已知真实 $y$ 时可以计算损失。攻击器用辅助成员数据训练，在验证数据上定阈值，并在独立审计集统计成员命中率和非成员误报率。目标成员真值用于核验，不能作为攻击器输入。该流程不承诺攻击成功，还须报告权限、查询预算与成员先验。

影子模型中的成员差异能否迁移，取决于它是否代表目标训练。数据增强、早停或分布不同，都可能使已学规律失效。总体攻击准确率较低也未必无害：它可能在少数敏感记录上成功。因此，应把平均值与逐记录、逐类别及低假阳性区域的结果一起报告。

Carlini 等的**似然比攻击**（Likelihood Ratio Attack, LiRA）针对每条待检记录作比较。辅助训练分别估计包含和不包含该记录时的分数分布，再判断目标分数支持哪种假设。该研究用变换后的置信度拟合分布，并强调在很低假阳性率下报告真阳性率[3]。

令记录 $z$ 的观测分数为 $s$，包含与不包含它时的密度分别为 $p_{\text{in}}(s \mid z)$、$p_{\text{out}}(s \mid z)$。理想检验比较两种解释的相对可能性：

$$\Lambda_z(s)=\frac{p_{\text{in}}(s \mid z)}{p_{\text{out}}(s \mid z)}. \tag{16.2}$$

[3] N. Carlini, S. Chien, M. Nasr, S. Song, A. Terzis, F. Tramer, *Membership Inference Attacks From First Principles* In arXiv preprint arXiv:2112.03570, 2022

分母为正时，上式是普通密度比；分母为零而分子为正时取 $+\infty$。两密度都为零的分数集合在两个假设下均为零概率，可任意约定该处比值而不改变检验结果。用 $P_{\text{in}}$、$P_{\text{out}}$ 表示这两种分数分布。对于完全指定的两个简单假设，在 $P_{\text{in}} \ll P_{\text{out}}$ 且假阳性率上限处于 0 与 1 之间时，按大似然比拒绝并在边界适当随机化的检验具有最大功效（可参考第一卷“随机变量”章的 Neyman–Pearson 引理）。有限辅助训练只能估计密度，经验 LiRA 因而不能直接继承无条件最优性。逐记录比较旨在区分原有难度与训练参与带来的优势：同是 0.95 预测概率，一封邮件若在两种假设下都容易预测，似然比可能接近 1；罕见邮件若只在参加训练时常得到该分数，似然比才可能明显大于 1。影子模型提供学习成员规律的一般流程，LiRA 在此基础上明确逐记录的双假设比较。

**示例 16.1　成员先验改变结果的含义**　设候选中真实成员占 1%，检验真阳性率为 0.8、假阳性率为 0.1。一万条候选预计检出 80 个真实成员，却同时误报 990 个非成员；全部阳性中真正的成员约占 7.5%。即使检验在成员与非成员各半的数据上结果尚可，实际低先验下的阳性可信度也可能很低。这个教学例子要求报告先验，而不能只移用平衡测试集的表现。

**发布模型中的训练数据提取**　知道一封邮件参加训练，只取得了一个二元事实；恢复内容则可能取得整段私人信息。Carlini 等以 GPT-2 研究查询中复现训练序列的情况，区分文本概率高与实际能够提取文本。实验显示发布模型可能暴露训练片段，平均泛化误差不足以概括这种风险[4]。

[4] N. Carlini, F. Tramer, E. Wallace, M. Jagielski, A. Herbert-Voss, K. Lee, A. Roberts, T. Brown, D. Song, U. Erlingsson, A. Oprea, C. Raffel, *Extracting Training Data from Large Language Models* In 30th USENIX Security Symposium, 2021

生成常见句子未必说明恢复了特定训练内容。受控实验可加入来源唯一的合成标记，再检验复现；真实数据实验则需核来源、去重并与对照语料比较。合成标记便于比较机制，却可能不同于自然记忆；真实内容更接近应用，来源证据不足时又可能混入公开重合或猜测。报告要保留这些证据强度差异。

邮件例子先生成不含真实个人信息的唯一项目编号，仅写入指定训练邮件，并保留无该编号的对照语料。训练后固定提示组、解码规则和一次完整试验的查询预算 $k$，保存全部输出并计准确复现次数。随机解码时，以独立种子重复整次试验，用至少提取一次的试验比例估计该预算下的成功率；确定性过程报告实际结果，重复相同输出不增加证据。还需与未训练该邮件的模型或对照训练比较，自适应改提示所花的查询也计入预算。所得结论是指定策略的可提取性，不能穷尽模型内部是否保有信息。遗忘审计可复用同样提示与预算，比较删除前、删除后及重训练参照。

**共享更新中的输入重构**　共享更新使审计还需回到训练中途。Zhu 等的梯度深度泄露（Deep Leakage from Gradients, DLG）在模型与梯度已知时搜

索候选输入和标签，使它们产生相近梯度。结果说明梯度可以携带私人样本信息；恢复程度仍取决于模型、批次和共享梯度等实验条件，不能把它当作天然匿名摘要[5]。

[5] L. Zhu, Z. Liu, S. Han, *Deep Leakage from Gradients* In Advances in Neural Information Processing Systems, 2019

线性模型提供容易核算的例子。单条记录采用平方损失 $\ell = \frac{1}{2}(\boldsymbol{w}^\top \boldsymbol{x} - y)^2$，参数梯度为 $(\boldsymbol{w}^\top \boldsymbol{x} - y)\boldsymbol{x}$。残差和梯度非零时，即使不知道残差数值，观察者也得到关于 $\boldsymbol{x}$ 方向的限制；再取得偏置梯度，会增加信息。这个关系只说明没有传原文仍可能传出内容线索，不能证明任意模型都能精确恢复。保护应覆盖实际可见更新，而非仅检查请求是否带原始字段。

重构审计应固定已知模型、更新轮次、批次大小和辅助信息，在受控数据中保留真实输入作参照。恢复结果既要与真值比较，也要与仅凭公开先验的猜测比较。图像外观、文本主题相近和私人字段精确一致，是不同强度的证据。常见结构恢复不足以确认特定记录；少量私人字段准确恢复，也不能因整体误差大而忽略。

### 16.2.2 基于数据流与实现的过程核查

过程核查将承诺逐项对应到数据流与执行条件。直接访问部分检查采集字段、身份权限、存储副本、日志、检索接口和工具接收者，寻找原文绕过保护的位置。统计保护部分检查发布算法是否具备形式机制所需前提，判断已经允许发布的信息是否满足约束。

可为邮件列处理清单：保存到哪里、谁能读取、经历哪些变换、留下什么中间状态、向外输出什么。配置和实现说明再与受控执行记录对照，验证访问拒绝是否生效、日志有无原文，以及备份和调试接口是否遵循相同限制。流程图给出预定路径，不能单独证明运行程序确实按图执行。

DP 实现要依次核对保护单位、敏感度、噪声分布、抽样与组合。敏感度是改变一个保护单位时，按所选距离或范数计算的最大输出变化；标量绝对值、票数向量的 $\ell_1$ 范数、梯度的 $\ell_2$ 范数服务于不同机制。调用加噪函数本身未保证尺度正确。逐记录裁剪却把参数解释为用户级，会漏掉同一用户多条贡献的联合影响。

私有数据还可能参与参数选择、早停、超参数搜索和中间结果发布。这些依赖若不在分析中，最终模型就未必具有所声称保证。检查应覆盖随机数实现、日志及其他渠道；保护某个发布接口的证明不包括系统另外输出的原文。

隐私台账应让人从发布版本还原保证。至少要绑定数据和模型版本、保护单位与邻接、贡献限制、抽样实现、噪声参数、会计方法及版本、目标 $\delta$、全部可见发布和累计消耗。旧模型或旧接口仍可观察时，历史输出仍属于联合会计；当前回滚或替换不能抹去这些消耗。

仍以关键词计数核验这条链。若承诺增加或删除一封邮件时满足纯 $\epsilon$DP，每封邮件的计数贡献须限定为 0 或 1，噪声按敏感度 1 校准，并登记同数据上的其他发布。核验沿原始字段、计数规则和随机输出逐步进行，配置中的 $\epsilon$ 只是其中一项。

一封邮件若含关键词一百次，按词频相加就可能贡献 100，原敏感度 1 证明随之失效。按旧尺度加噪后，输出即使显得随机，也没有实现原承诺。单元测试可查贡献截断、噪声尺度和重复发布登记；上界仍需对全部允许输入证明，不能由少量测试替代。第 16.3.3节会推导相应机制。

安全聚合和加密计算对应另一组核验对象：参与者能观察什么、哪些串通被允许、协议依赖什么条件。隐藏计算过程尚未限制公开结果泄露多少。过程保密与统计输出保护需分别留证，再检查组合后的数据流。

### 16.2.3 验证结论与适用边界

审计结论须与实际比较对象对应。控制来源等混杂因素后，成员判别成功支持参与信息可被利用；内容提取和重构还需证实恢复内容的来源与特异性。它们恢复的信息不同，不能未经论证就当作同等强度的泄露证据。

成功攻击可以反驳过强的保护声明；失败只表明在这项攻击及其资源限制下尚未发现泄露，不能证明所有输出事件都满足 DP。理论参数很大而某个攻击成功率低时，二者也不能相互抵消：一个较弱攻击并未说明参数已经无关紧要。

受控攻击还可为参数给出必要下界。固定相邻数据对和检验事件，真实真阳性率 $t > \delta$、假阳性率 $f > 0$ 时，须有 $\epsilon \geq \log((t-\delta)/f)$。实验只取得率的估计，应以真阳性率置信下界和假阳性率置信上界计算，而非把零次误报当作 $f = 0$。普通成员分类若未实现相邻比较，也不能直接反推 DP 参数。证据强度由实验与定义的对应决定。

保护的代价也要评价。输出与数据无关的噪声可满足很强限制，却可能无法完成任务。不同群体的样本数和信号强度不同，相同噪声也可能造成不同效用损失；应结合第 13章按群体检验，并报告成本。

公平审计可把敏感属性读取限定在受限环境，由指定角色计算预定群体指标。训练和线上决策不因此获得权限，对外仅发布所需统计，并检查小群体、交叉查询和重复发布。最小组规模、访问限制和限流可缓解直接暴露，却不能单独保证个体影响上界；后者还需限制每人贡献、保留跨接口查询历史，并以匹配邻接的可组合机制分析联合发布。验收也分两项：公平证据核重要群体的样本是否充分、统计分母是否有效，隐私证据核属性接收者、发布内容和联合观察边界。删除全部属性会丧失测量差异的证据，无限制开放又会增加暴露；两项要求须共同满足。

## 16.3 隐私保护的实现

措施沿私人信息进入系统、参与训练和交付结果安排。采集存储限制输入和明文接触者，训练限制数据对参数与中间更新的影响，发布推理限制接收者所得信息，并处理运行中新增的私人上下文。各处保护可组合，其验证对象由前节的数据流与输出承诺确定，不能仅由一处保护推断全程成立。

### 16.3.1 数据采集与存储中的保护

采集之前先问任务是否需要这项信息。省去无关字段会减少保护范围；必要字段须确定用途、访问者和保留时间。不过，即使数据库访问受限，公开一个人数为 1 群体的精确均值仍能暴露个人值，因此还要分析输出。

最小化需要在具体字段上验证。例如，先检验移除邮件地址和私人编号后，正文特征是否仍能分类，再决定是否收集或长期保存这些字段。只需本地预测时，计算可留在设备，同时检查遥测和日志有无上传原文。省去收集可避免该路径风险，去姓名或改账户代号却不能保证匿名；正文、时间和关联记录仍可能识别人。

必要信息可以按角色限制访问，隔离用途，约定期限，并在传输和存储时加密。加密限制的是无密钥者的读取能力，解密处理方与最终接收者仍可见明文。因此，解密后的用途和输出也需约束，数据库加密不能证明模型不会泄露训练内容。

必须收集个人值、却不应让接收方准确知道它时，可在发送前本地随机化。这样保护的是交给接收方的输入。接收方先持有明文、随后才随机发布，属于另一种信任安排，需要分别说明。

二元**随机响应**（randomized response）给私人位加入发送前的随机性。对 $x \in \{0,1\}$，以 $p = e^{\epsilon}/(1+e^{\epsilon})$ 的概率发送 $x$，否则发送 $1-x$。两种输入产生任一消息的概率比至多为 $p/(1-p) = e^{\epsilon}$，故有本地纯 DP。设私人位为 1 的比例为 $\mu$、接收位为 $Y$，则 $\mathbb{E}[Y] = (1-p) + (2p-1)\mu$。$\epsilon > 0$ 时可用 $(\bar{Y} - (1-p))/(2p-1)$ 估计 $\mu$；$\epsilon$ 趋近 0 时分母也趋近 0，误差会放大。这个例子把保护强度同样本量和统计精度的代价相连。

### 16.3.2 训练过程中的保护

训练要保留群体规律，同时控制单个对象改变发布模型的能力。可限制更新贡献，也可只让私有模型提供受保护的监督标签；二者都须分析相邻数据下的发布分布。选噪声尺度之前，先以指定距离或范数限制最大输出变化，即敏感度。协作方若能看到发布前更新，还需保护这些中间观测。

**限制每次更新中的贡献** 多步训练累积各样本的影响。**差分隐私随机梯度下降**（differentially private stochastic gradient descent, DP-SGD）先限制单样本梯度，再对聚合更新加噪，使重复更新可以共同纳入隐私分析[6]。

令批次有 $b$ 条样本，梯度为 $\boldsymbol{g}_i$，用 $c > 0$ 限制其二范数：

$$\begin{aligned} \bar{\boldsymbol{g}}_i &= \boldsymbol{g}_i \min\{1, c/\|\boldsymbol{g}_i\|_2\}, \\ \tilde{\boldsymbol{g}} &= \frac{1}{b}\left(\sum_{i=1}^{b} \bar{\boldsymbol{g}}_i + \boldsymbol{Z}\right). \end{aligned} \tag{16.3}$$

零梯度仍取零，$\boldsymbol{Z}$ 为按隐私分析校准的高斯噪声。固定批次中替换一条记录，梯度和的敏感度至多 $2c$。增加删除、抽样或用户分组的约定不同，就要重新匹配敏感度与会计。随后以 $\tilde{\boldsymbol{g}}$ 更新，登记各步消耗。

式 (16.3)的顺序决定分析单位：各样本分别求梯度和裁剪，再求和、加噪并更新。整批相加后裁剪虽也得到有界向量，却改变了机制，不能直接用逐样本抽样分析。即使最后只发布模型，也要查日志和检查点是否另暴露未受保护梯度。

图 16.2顺次展开一次更新的裁剪、聚合、噪声和参数更新；账本还需累计全部训练步。

[6] M. Abadi, A. Chu, I. Goodfellow, H. B. McMahan, I. Mironov, K. Talwar, L. Zhang, *Deep Learning with Differential Privacy* In Proceedings of the 2016 ACM SIGSAC Conference on Computer and Communications Security, 2016, pp. 308–318

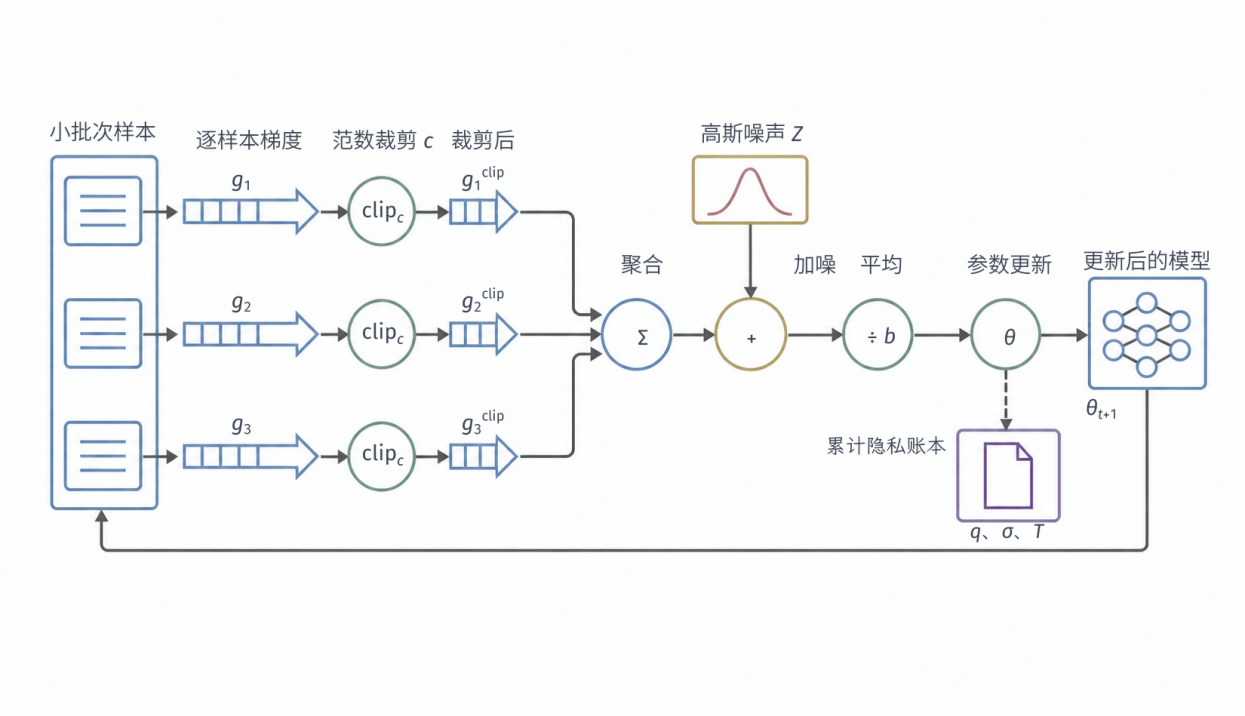


图 16.2 DP-SGD 的一次更新。分别计算批次梯度 $\boldsymbol{g}_i$，按 $c$ 取 $\text{clip}_c(\boldsymbol{g}_i) = \boldsymbol{g}_i \min\{1, c/\|\boldsymbol{g}_i\|_2\}$，随后求和、加入高斯噪声 $\boldsymbol{Z}$、除以 $b$ 并更新。账本结合抽样率 $q$、噪声尺度 $\sigma$、步数 $T$ 等累计消耗，分析必须对应保护单位、邻接关系和抽样约定。向量长度及高斯曲线只示意机制。

裁剪使单样本影响有界，也可能引入偏差；噪声降低更新的可区分性，同时影响优化。预算须结合训练步数、抽样率和噪声强度计算。用户级方案还须控制该用户的总贡献，不能把逐记录裁剪后的多项贡献无限制相加。

噪声可写为 $\boldsymbol{Z} \sim \mathcal{N}(\mathbf{0}, \sigma^2 c^2 \boldsymbol{I})$，$\sigma$ 为相对阈值 $c$ 的噪声乘子。独立泊松抽样以概率 $q$ 选各记录，批量大小随机；一种明确机制用数据集大小 $n$ 和期望批量 $qn$ 归一化。改为实际批量归一化或固定大小不放回抽样时，须按实现重写机制，匹配其邻接和抽样会计，不能直接用固定 $b$ 公式。Abadi 等以裁剪、噪声和矩会计分析深度训练的重复访问；后续也常用第 16.3.3节的 Rényi 会计合并更新消耗。

优化与隐私参数要分开比较。固定 $q, \sigma, T$（$T$ 为步数）及邻接约定，改变 $c$ 时按相同比例缩放噪声，通常不改变由噪声尺度与敏感度的比值决定的隐私界。优化轨迹却会变化：小 $c$ 压缩更多梯度，大 $c$ 增加绝对噪声。批量变大也改变平均更新的信噪比、抽样率及完成同轮数所需步数，因此须固定训练预算口径，才能判断隐私有无改善。

公开预训练可帮助保留效用。只要未使用本次保护的数据，会计就从后续私有访问开始；冻结部分参数虽可省计算，其余更新仍需裁剪和完整分析。若用私有数据选模型、构词表或筛样本，这些前置依赖也属于发布算法，不能因在梯度下降之前就不计。

**限制监督标签中的私人知识** 若大模型每次更新加噪的损失过高，可让私有模型只回答有限的受保护监督查询。**教师集成的私有聚合**（Private Aggregation of Teacher Ensembles, PATE）将敏感数据划为互不重叠分区，教师各用一片训练；学生以非敏感输入查询，再用带噪投票标签学习。保护接口是聚合，教师自身不发布[7]。

记第 $j$ 类票数为 $v_j(\boldsymbol{x})$，一种聚合返回 $\arg\max_j \{v_j(\boldsymbol{x}) + Z_j\}$。固定分区规则，一条记录至多改变一个教师的票；从一类移到另一类，票数向量的 $\ell_1$ 变化至多 2。该界来自数据隔离，并不要求教师优化凸性。一个用户跨多个分区时，可改变多位教师，必须重算用户级影响。

共识高时，一票通常难以改变答案；近乎平票时则更容易改变。可扩展 PATE 采用高斯聚合，以带噪共识阈值决定是否回答，用投票差距细化隐私会计。回答与否也依赖私人数据，该门控同样需要计入消耗[8]。

拒绝低共识查询也会筛选学生的训练数据。罕见邮件可能更难获得共识，应按群体检查标签获得比例与学生效用；这个比例不同于预测集合覆盖率。实际顺序是先训练保持私有的教师，再为来源明确的非敏感输入查询带噪标签，最后训练学生，每次新查询都计入访问。PATE 把接口放在监督标签上，教师可用不同内部算法，却需要适合学生的非敏感输入，并受查询数和共识不足限制。DP-SGD 直接控制私有更新，不需教师分片或

[7] N. Papernot, M. Abadi, Ú. Erlingsson, I. Goodfellow, K. Talwar, *Semi-supervised Knowledge Transfer for Deep Learning from Private Training Data* In International Conference on Learning Representations, 2017

[8] N. Papernot, S. Song, I. Mironov, A. Raghunathan, K. Talwar, Ú. Erlingsson, *Scalable Private Learning with PATE* In International Conference on Learning Representations, 2018

这种输入。比较两者须先统一保护单位，最终噪声数值不能单独代表保护强弱。

学生若只使用公开输入、受保护标签和独立随机性，给定这些标签后便与私人数据条件独立，可以应用后处理性质。继续读取教师、原始记录或其他数据依赖状态，就会新增需要会计的访问；将学生放回私人数据训练也属于这种情况。

图 16.3示意教师与学生之间的边界。公开查询输入取得受保护聚合标签用于学生学习，私有样本没有直接交给学生。

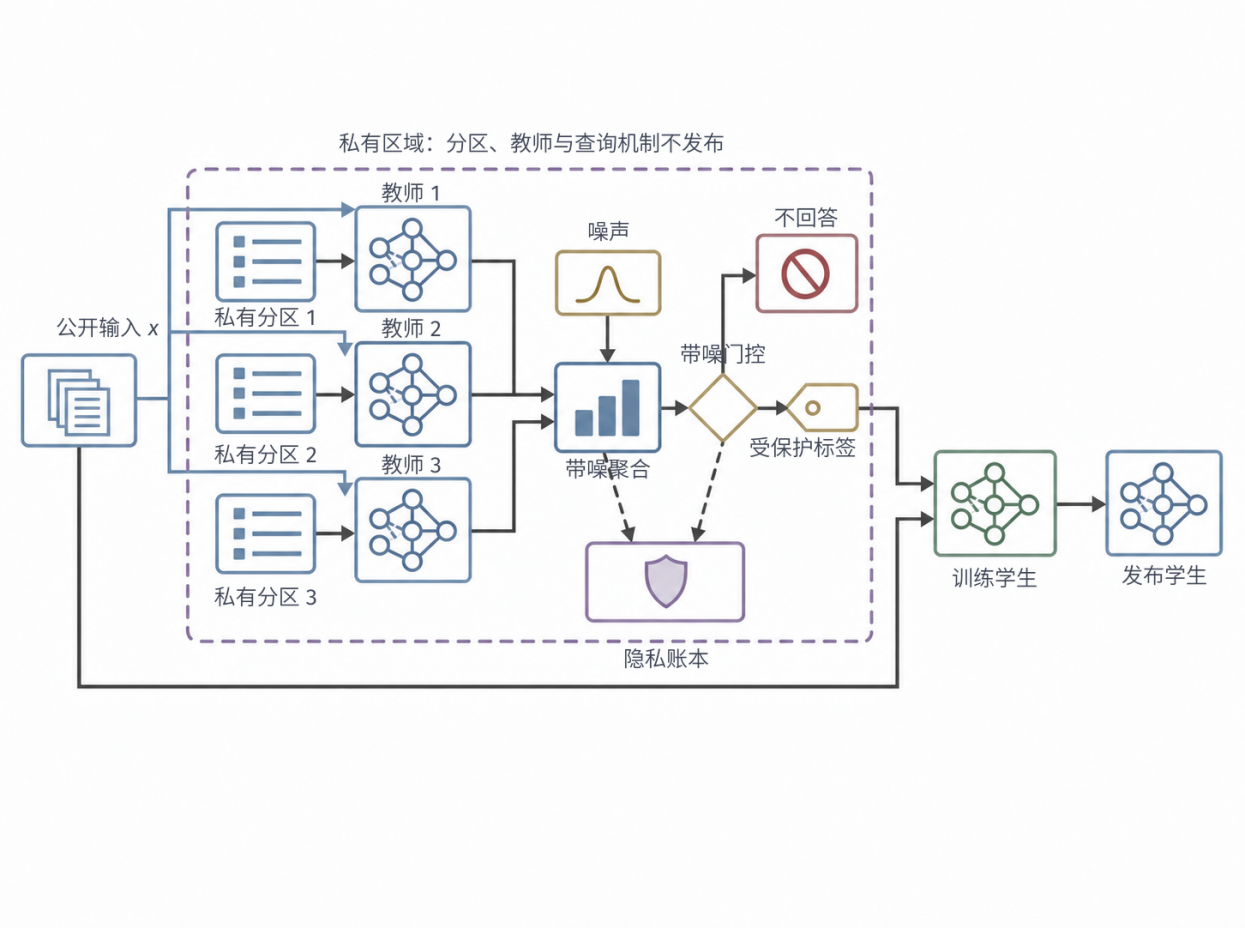


图 16.3 PATE 的信息流。各教师用互不重叠的私有分区训练并保持不发布，非敏感公开输入取得各教师投票。加噪聚合和带噪门控产生受保护标签，低共识可不回答；两项决定均计入查询隐私消耗。学生仅以公开输入和受保护标签训练后发布，不能接触私有样本或单个教师。蓝线为公开查询，灰线为训练与投票，虚线为隐私记账；条形表示投票机制，不是实测数值。

**协作方可见的中间更新** 最终发布的保护尚未处理参与者可见的训练更新。服务器和其他客户端可能在发布前取得这些观测，所以要先列明各方权限与允许串通的范围，再决定怎样隐藏中间信息。

安全聚合（secure aggregation）把服务方的可见结果限制为多个参与者的聚合；安全多方计算（secure multi-party computation, MPC）和同态加密（homomorphic encryption, HE）在受限的中间可见信息下完成指定计算；可信执行环境（trusted execution environment, TEE）则以隔离执行和硬件假设为依据。它们解决计算过程的保密问题，若最终模型仍保有私人内容，还须分析输出泄露。

Bonawitz 等针对客户端向服务器提交向量并求和设计安全聚合协议。客户端更新先带掩码发送，聚合时掩码抵消，协议另处理部分客户端退出后的恢复。论文按对手与串通条件分析服务器可得总和而不可得单项更新的范围[9]。

[9] K. Bonawitz, V. Ivanov, B. Kreuter, A. Marcedone, H. B. McMahan, S. Patel, D. Ramage, A. Segal, K. Seth, *Practical Secure Aggregation for Privacy-Preserving Machine Learning* In Proceedings of the 2017 ACM SIGSAC Conference on Computer and Communications Security, 2017

总和本身也可能泄露。其余贡献已知而仅剩一名未知参与者时，观察者可从总和确定该人的贡献；多轮高度重合人群的统计，也可能通过作差提供线索。因此，参与人数、串通阈值与发布规则须和安全聚合一起说明。分布式加噪还需证明噪声由谁产生、多少诚实参与者留存，以及退出后总噪声是否仍足够。

图 3.14将本地记录、上传更新和中心聚合区分开。记录虽留在设备，更新仍是由私人数据产生的观测，须按上述权限与串通条件检查。

联邦学习将计算移到数据所在位置，本身不提供这些隐私条件。本地记录级 DP-SGD 与裁剪客户端总更新的用户级方案，保护的单位不同。信任中心时可在安全聚合总和上由服务器加噪；不信任中心时，需要客户端共同提供足量噪声或采用其他信任安排。通信加密、聚合保密和统计输出保护应连接到同一数据流，分别实现各自承诺。

### 16.3.3 结果发布与推理使用中的保护

开放权重、限制查询和发布统计表，给接收者的观察能力不同。发布前应逐项确认实际可见内容：减少无关分数、原始字段和调试信息，可收窄直接暴露；限接口和查询数，可减少某些攻击的观测。要宣称 DP，仍需针对相应机制分析，不能由这些操作限制单独推出。

**发布统计量中的个体影响** 可信管理者已拿到明文后，还要控制公开统计量对个人的暴露。小群体精确统计或反复差分查询，即使不含原文，也可能确定个人值。下面以统计量的发布分布作为保护对象。

设要发布实值统计 $F(D)$。在给定相邻关系下取 $\Delta F = \sup_{D\sim D'} |F(D) - F(D')|$，限制一个保护单位能够造成的最大变化，再据此选择噪声：

$$M(D) = F(D) + Z, \qquad Z \sim \text{Laplace}(0, \Delta F/\epsilon), \tag{16.4}$$

这里要求 $\epsilon > 0$ 及 $0 < \Delta F < \infty$。敏感度为零时，统计量对相邻变化不变，无需为此加噪；敏感度无界时，则须先限定数据域或贡献，或另选机制，不能使用一个有限拉普拉斯尺度。

式 (16.4)为何具有纯 $\epsilon$DP，可以直接比较同一输出位置 $u$ 的密度：

$$\exp\left(\frac{|u - F(D')| - |u - F(D)|}{\Delta F / \epsilon}\right) \le e^{\epsilon},$$

三角不等式把分子差限制为敏感度，对任意输出事件积分，就得到上述 DP 概率限制的 $\delta = 0$ 情形。噪声尺度由此同最大数据影响相连，不能先任意加噪再为它命名隐私参数。

图 16.4以相差一条记录的计数比较随机发布。上部将准确值与同分布噪声相加，下部展示所得分布。观察者只取得一次随机输出，定义限制的是两种数据下所有事件的概率关系，并不要求两次可能输出取同一数值。

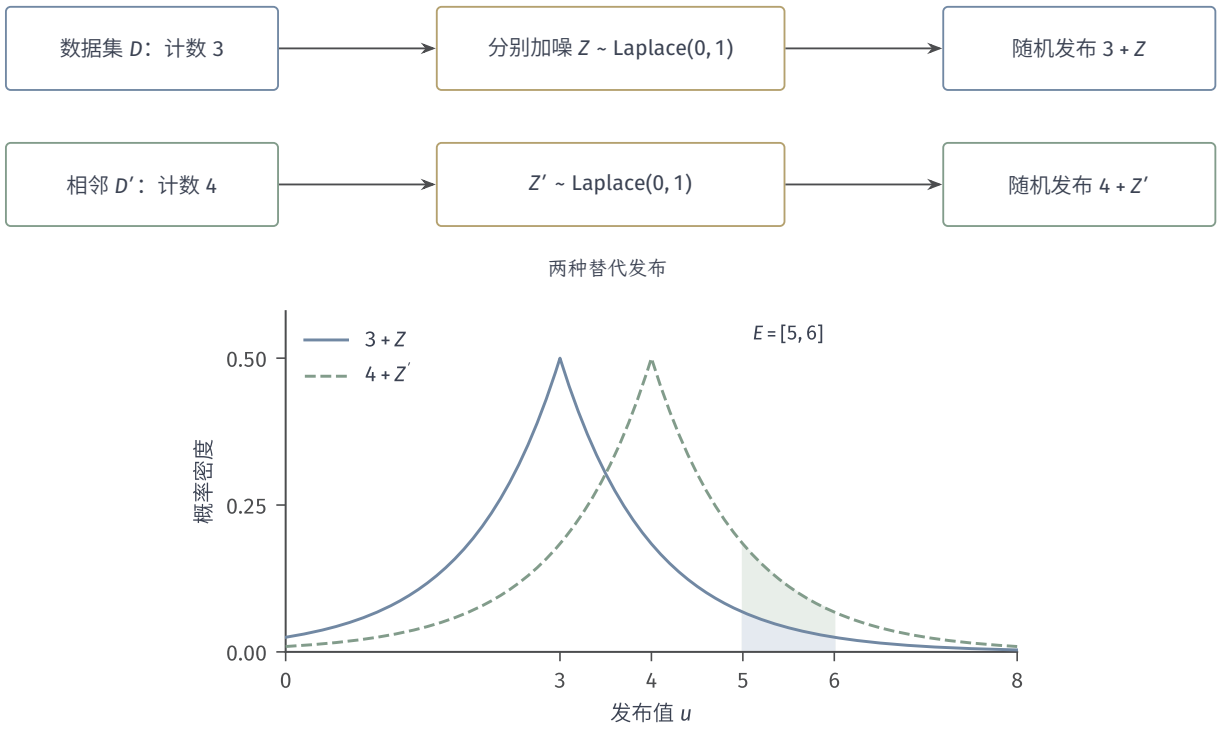


图 16.4　相邻计数的随机发布。两数据集仅差新增一条记录，准确计数为 3 和 4；各反事实机制都使用尺度 1 的拉普拉斯分布，故 $\Delta F = 1$、$\epsilon = 1$、$\delta = 0$。两行是替代发布情形，不表示共同发布两次，也未规定联合耦合。每一行由准确计数经加噪得到随机发布，下方实线与虚线为解析密度，阴影比较同一事件 $E = [5, 6]$；横轴只画部分范围。一次输出的保护须对全部相邻数据和全部事件成立，曲线重叠只是示意。

关键词邮件数每条贡献至多 1，记录级敏感度为 1。取 $\epsilon = 0.5$ 时，加入尺度 2 的 Laplace 噪声；相差 1 的两计数会产生重叠输出，不能再由一个准确整数确定目标邮件是否存在。若保护一名用户且每人最多贡献 10 封

相关邮件，敏感度变为 10，同 $\epsilon$ 要求尺度 20，除非另限制贡献。这个代入例子把保护单位、噪声和效用代价对应起来。

> **示例 16.2 计数与平均值的不同要求** 增加删除相邻下，人数计数的敏感度为 1。均值则需要另一组条件：固定 $n$ 条记录，按替换一条定义相邻，数值预先限于 $[0,1]$，敏感度才为 $1/n$。取消值域限制可能使它无界。两例的邻接约定不同，不能仅凭都叫统计量便使用同一尺度。

**推理上下文与结果接收者** 推理新增的信息流也要逐处限制。检索私人文档、调用工具或保存对话日志，会把敏感内容送入新的接口。应提供必要上下文、限制工具字段，并确认输出内容及接收者。若这类输入也承诺形式保护，其新访问必须纳入所用机制分析。

这里保护当前请求的私人信息，范围已超出训练记录。模型即使满足训练数据 DP，收到新邮件后直接转交外部工具，仍可能泄露请求。上下文进入模型、字段进入工具和结果交给接收者，都需要各自的信息边界；训练保证不能自动覆盖新增输入。

权限控制可在检索前实施，只把用户有权查看的文档送入上下文。随后工具仅获任务必要字段，回复与工具请求核接收范围，日志限制保存内容。输出过滤可拦已知标识或模式，却会遗漏改写和间接推断，也可能误删合法内容，需分别用结果检验和过程核查确认。过滤测试有效仍不足以宣称上下文形式隐私成立。

**多次发布的累计保护强度** 已有发布 $M(D)$ 之后，若随机映射 $K$ 给定该结果便与 $D$ 条件独立，即仅使用 $M(D)$、公开信息和独立随机性，$K(M(D))$ 就不增加 DP 参数。后处理事件可转写为原输出上的随机检验，继续受相同 DP 参数限制，这就是后处理性质。若另读由 $D$ 生成、却未纳入 $M(D)$ 发布保证的额外缓存、模型或统计量，就会新增数据依赖，不能应用这项纯后处理结论。

重新读取数据运行机制，需要组合保护。基本界将各步 $\epsilon, \delta$ 分别相加；自适应时，每步给定先前输出仍须对同一邻接满足所声称的条件界。利用结构可得到更紧会计，但重复试验和模型选择仍须纳入。查询已发布私有模型而不新增数据访问，与每次重新读取私人上下文，属于不同过程。

同一保护对象影响多个发布时，观察者可以联合利用它们，预算也必须累计。以下组合用于训练更新和持续服务，可跨采集、训练、发布阶段使用，并不是另一个处理阶段。

同批邮件以 $\epsilon = 0.5$ 计数，重新抽噪发布三次，基本组合得到纯 DP 上界 1.5。只把已发布的一次计数画图、换单位或再显示，则是后处理，不新增

该预算。调用分属不同网页或功能，也不能拆开忽略同一对象的访问；会计应覆盖观察者联合可见的结果。

训练更新常达数千次，每步都转成 $(\epsilon,\delta)$ 再求和可能过松。记要比较的两种输出分布为 $P,Q$。对已选阶数 $\alpha>1$，当 $P\ll Q$ 时，Rényi 散度使用 $Q$ 下密度比 $\mathrm{d}P/\mathrm{d}Q$ 的 $\alpha$ 阶矩衡量差异。绝对连续性失败或该阶矩无限时，散度取 $+\infty$（可参考第一卷“概率分布”章的高于一阶的 Rényi 散度定义）。

Rényi **差分隐私**（Rényi differential privacy, RDP）要求每一对相邻数据的输出分布都有同一个散度上界。用 $P_D$ 表示 $M(D)$ 的输出律，则在已声明的邻接下，所有 $D\sim D'$ 均须满足 $D_\alpha(P_D\|P_{D'})\le\rho(\alpha)$。这里固定保护单位、阶数和统一上界，不能只检查平均数据对。Mironov 建立此定义及组合、后处理和转换性质[10]。

[10] I. Mironov, *Rényi Differential Privacy* In 2017 IEEE 30th Computer Security Foundations Symposium, 2017

第 $t$ 步若在同一邻接下、给定任意此前输出仍有统一的 $\rho_t(\alpha)$ 界，完整输出序列就有 $\sum_t\rho_t(\alpha)$ 的组合上界；自适应选择机制也需保留这个逐历史条件（可参考第一卷“概率分布”章的“重复与时序观测的信息累积”讨论）。事先指定 $\delta\in(0,1)$ 后，可转换为

$$\epsilon(\delta)=\inf_{\alpha>1}\left\{\sum_{t=1}^{T}\rho_t(\alpha)+\frac{\log(1/\delta)}{\alpha-1}\right\}. \tag{16.5}$$

取下确界只在已证明有效的阶数界中选择，不再读取私有数据。不含抽样的高斯发布有 $\rho(\alpha)=\alpha\Delta_2^2/(2s^2)$，$\Delta_2$ 为向量统计的二范数敏感度，$s$ 为逐坐标噪声标准差。抽样会改变曲线，不能简单把抽样率乘到最终 $\epsilon$；独立泊松和固定大小不放回需不同放大分析。选择样本若依赖私人数据，也不能沿用数据独立抽样的放大结论。

## 16.4 数据撤回与模型消除

邮件撤回后，我们希望移除的是这些指定记录的训练影响，称为**机器遗忘**（machine unlearning）。本节“模型消除”指这一目标，并非删除或停用整个模型。清除文件、阻止文本输出和消除训练影响，各有自己的验收对象。

用 $A$ 表示训练算法、$D$ 表示原数据、$F$ 表示撤回记录、$U$ 表示模型更新程序。图 16.5区分保留数据与模型更新：数据清理并不改写旧模型，更新后的影响则要同从未使用 $F$ 的重训练比较。一个提取测试没有恢复私人片段，只支持该测试结果，尚未说明全部训练影响消失。

集合差先按记录身份定义，并限定观察者只取得替换后的新发布模型，不再持有旧模型、旧回复、日志或辅助状态。在这一视图内，精确遗忘要求

$$U(A(D),D,F)\overset{\mathrm{d}}{=}A(D\setminus F). \tag{16.6}$$

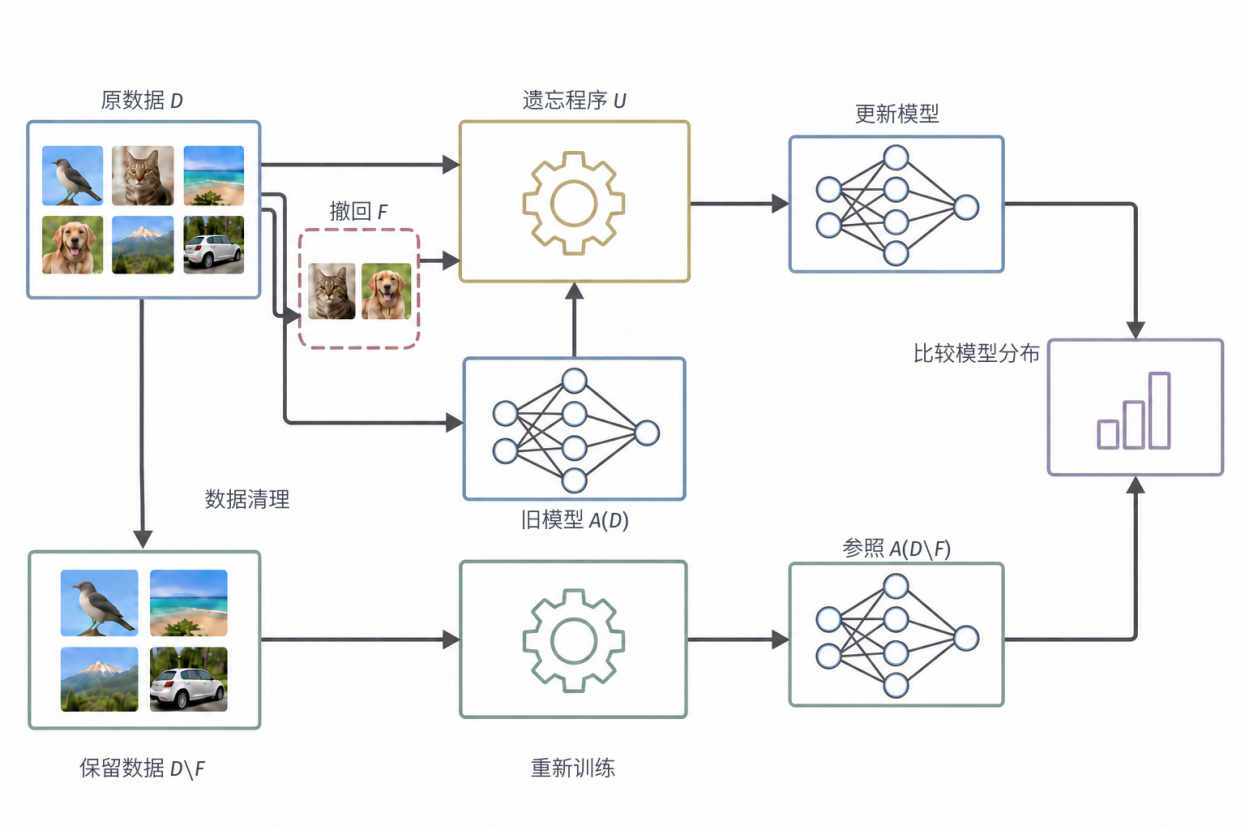


图 16.5 数据清理与训练影响消除。删除记录得到 $D \setminus F$，旧模型 $A(D)$ 仍保持原状态；$U$ 另外读取旧模型、原数据和撤回集合进行更新。应比较更新结果与从未使用 $F$ 的重训练模型分布：精确遗忘要求同分布，近似遗忘需指定距离或可区分性标准。

$\stackrel{d}{=}$ 比较训练与遗忘随机性产生的已发布模型分布，并非一个固定模型对某个请求的预测分布[11,12]。右侧由从未使用撤回记录的训练得到。观察者若还能联合读取旧模型、回答或其他状态，就要比较联合观察分布；新模型边缘同分布不能收回已披露的信息。程序可保存额外状态，但可见状态同样须纳入参照。

近似遗忘把同分布放宽为在指定距离或可区分性标准下接近。也可以另定义参数、预测或攻击结果的比较，但行为与攻击只考察模型经过特定观察映射后的量。少量请求上结果接近，除非另有证明，不能推出整个发布模型分布接近重训练。

DP 与遗忘各自比较不同对象。DP 训练限制参与对输出的影响，遗忘在撤回后比较指定记录删除时的重训练。二者可配合，使用 DP 却不能单独证明任意撤回要求已经完成。

一次撤回首先要确定范围，停用相关数据，清理可控制的副本和衍生状态，并隔离尚不能清除的部分。这些是每项请求都要做的工作。数据已进入训练结果时，再在完整重训练、局部重算和参数修正中选择满足遗忘标准的方案；三者互为备选，无需依次执行。正式处置完成前的输出限制属于过渡措施。最后分别验收资产、接口和模型影响，同时计完整流程的时间与资源。

### 16.4.1 撤回范围与数据资产清理

定位时利用稳定记录标识、用户关联和计算依赖，找到原始文件、清洗副本、特征缓存、检索索引、向量记录、训练快照及相关日志。用户级撤回不能止于账户表的一行；记录同时涉及多人时，还要指定删除整条还是其中字段。范围确定后，后续处置才有可核对清单。

快速响应依赖事先保存的数据去向。记录与数据版本、索引项、训练任务、模型版本之间的映射，可用于生成撤回任务。确认请求后，先阻止数据再入训练队列、检索和新副本，随后按存储依赖清单删除或重建，并核正在运行任务有无旧快照。删除标记可以停止正常使用，物理副本真正清除则是另一个完成状态。

模型修正可能还要读撤回记录，所以清理顺序需与更新协调。贡献扣除需其统计量，部分参数修正需其损失；若必须读取原文，可在受限撤回环境完成，再删除工作副本。已有统计状态够用时可免读取，但状态本身也须核私人信息。停止正常训练和检索，不意味着立即销毁算法尚需的一切输入；临时副本的权限、存续期与最终清除仍属本次验收。

删除索引还需处理衍生缓存。文档移除后，向量、片段缓存和生成摘要可能继续被检索或复用；备份恢复时也应重新执行撤回记录，防止旧数据

[11] L. Bourtoule, V. Chandrasekaran, C. A. Choquette-Choo, H. Jia, A. Travers, B. Zhang, D. Lie, N. Papernot, *Machine Unlearning* In 2021 IEEE Symposium on Security and Privacy, 2021

[12] C. Guo, T. Goldstein, A. Hannun, L. van der Maaten, *Certified Data Removal from Machine Learning Models* In Proceedings of the 37th International Conference on Machine Learning, 2020, pp. 3832–3842

回流。无法立即逐条清理的归档，要明确隔离、清除计划及恢复限制。在线不可见只能描述当前接口，不能表述为所有副本已消失。

按存储和依赖清单验收，逐项区分完成、待处理和无法控制的副本，测试记录能否继续被检索、导出或训练，并绑定模型版本。审计日志需证明处置过程，也应避免再次保存完整私人内容。资产清理解决仍保存和再使用的问题，参数里的训练影响还须进入下一节的方案选择。

### 16.4.2 训练影响的消除方案

已经参与训练的记录，需要按遗忘标准、算法结构和可用状态选择消除方案。完整重训练直接生成参照，局部重算依赖可追踪计算，参数修正则从旧模型出发，近似求得删除后的结果。三者条件与证据不同；耗时少只说明计算节省，不能单独代表遗忘充分。

**完整重训练** 完整重训练在 $D \setminus F$ 上重新运行 $A$，直接生成式 (16.6)右侧的参照，代价是再处理保留数据和训练模型。它比较同一流程下的模型分布，不要求一组随机参数恰好重现。

参照还包括用 $F$ 完成的前置处理。词表、标准化、样本筛选和模型选择若依赖撤回记录，就须重算；受 $F$ 影响的优化器状态或初始化检查点，也不能直接作为从未读过 $F$ 的起点。公开预训练或中间结果只有确定独立于 $F$ 时才可复用。早停轮数、随机抽样及其他训练规则都属于 $A$，需要一起固定。

新模型完成后，还要切换服务、使旧缓存失效，记录覆盖的撤回请求。合并多项请求可以省去重复训练，等待期间却仍须限制旧数据和服务暴露，报告实际等待时长。进入批处理队列只是安排，不能据此把模型影响标为已消除。

**局部重算** 要减少重训练工作量，先确定记录影响哪些计算。模型若只依赖可更新统计，可扣除该记录的贡献；训练若事先隔离为多个部分，可只重算受影响的部分。两种节省均依赖已知计算结构，并不意味着任意网络参数中都能找到一条记录的位置。

Cao 和 Yang 将学习过程组织成可更新的求和形式，撤回时修改对应统计，减少对保留数据的重复处理。算法和前置处理须确实符合这一结构，并能追踪衍生数据依赖，才可采用贡献扣除[13]。

考虑仅用记录数 $n$ 和数值和 $S$ 计算 $\hat{\mu} = S/n$ 的教学估计器。撤回 $m < n$ 条记录，令其和为 $S_F$，可直接更新

$$\hat{\mu}_{-} = \frac{S - S_F}{n - m}.$$

[13] Y. Cao, J. Yang, *Towards Making Systems Forget with Machine Unlearning* In 2015 IEEE Symposium on Security and Privacy, 2015

数学上等同于重新对保留数据求均值，只需知道撤回贡献；实现仍有浮点误差。对 $1, 2, 3$ 删除 3，更新得 $(6-3)/(3-1) = 1.5$。这证明特定统计模型可以精确扣除，却不能推为深度训练中减回某个梯度即可：后续步骤依赖先前参数，也受该记录连带影响。

另一种结构在训练前隔离依赖。SISA 按分片、隔离、切片与聚合（Sharded, Isolated, Sliced, and Aggregated）组织训练：分片各自训练子模型，内部依序处理切片并保存检查点，最后聚合预测。删除记录时恢复到它首次进入之前的状态，再重算相关后续步骤。局部节省由预先隔离获得[14]。

例如，邮件预先分四片，每片含三个顺序切片，待删除记录在第二分片的第二切片。其他三子模型可保留，第二分片从第一切片末状态开始，在排除该记录后重算后两个切片。节省来自依赖隔离，而非从最终参数任意抽出记录影响。全数据上的标准化、词表和模型选择若仍共同计算，就会形成跨片依赖，必须一起处理。

分片增多会减少各子模型数据，也可能改变集成相对整批训练的效用；检查点越密集会增加存储和敏感状态管理成本。因此，评估不能只计一次删除时间，还要计初训、保存状态、常见请求分布和保留任务效用。给定删除条数时，应检验使受影响分片数或重算时间最大的请求位置，并固定所比较的重训练算法。

SISA 更新的参照应采用同样分片、切片和聚合规则，还要核删除后抽样与随机状态的处理。整批单模型本来是另一训练算法，不能用与它的比较宣称 SISA 输出分布相同。

**参数修正与近似遗忘** 依赖没有事先隔离时，可从当前参数出发，近似求得删除后的模型。参数改变量小，并不能直接说明指定记录的影响已被充分消除；需要另给误差和分布依据。

Guo 等的认证删除为一类正则化线性模型控制近似误差：牛顿更新逼近删除后的解，训练目标中的随机扰动再遮掩剩余误差。强凸性、平滑性等条件共同支撑保证，仅有小梯度残差还不足以证明删除成功[15]。

先看更新的优化作用。原参数为 $\hat{\theta}$，删除后的光滑强凸目标为 $L_{-}(\theta)$；在原参数处，梯度与海森矩阵为 $\boldsymbol{g}_{-}, \boldsymbol{H}_{-}$，一步牛顿近似为

$$\tilde{\theta} = \hat{\theta} - \boldsymbol{H}_{-}^{-1}\boldsymbol{g}_{-}. \tag{16.7}$$

目标局部近似二次时，此步可去除主要一阶偏差，剩余误差可由 $\|\nabla L_{-}(\tilde{\theta})\|_2$ 刻画。确定性误差再小，观察者仍可能利用精细参数差别识别记录。因此，认证还需把残差与随机扰动的分布连起来，证明输出按既定可区分性标准接近重训练。

[14] L. Bourtoule, V. Chandrasekaran, C. A. Choquette-Choo, H. Jia, A. Travers, B. Zhang, D. Lie, N. Papernot, *Machine Unlearning* In 2021 IEEE Symposium on Security and Privacy, 2021

[15] C. Guo, T. Goldstein, A. Hannun, L. van der Maaten, *Certified Data Removal from Machine Learning Models* In Proceedings of the 37th International Conference on Machine Learning, 2020, pp. 3832–3842

对无约束可微强凸目标,设强凸参数为 $\lambda > 0$,最优解为 $\theta^*_-$,则 $\|\tilde{\theta} - \theta^*_-\|_2 \leq \|\nabla L_-(\tilde{\theta})\|_2/\lambda$。这是残差控制参数误差的结论，强度尚不到输出分布隐私界。连续撤回需累计残差与认证预算，超出允许条件时可通过重训练恢复承诺。非凸大型语言模型不具备上述前提，不能直接使用强凸线性分析。

没有认证条件时，深度模型可尝试经验修正。在撤回样本上提高预测损失以压低相应答案概率，同时在保留数据上降低任务损失或约束预测变化。前项减少目标行为，后项限制附带损伤；若仅提高撤回损失，模型也可能靠破坏广泛能力达成。撤回准确率下降因此不是遗忘充分程度的单一指标。

负偏好优化（Negative Preference Optimization, NPO）针对语言模型遗忘更新的不稳定性，以原模型作参考，按目标序列在当前与参考模型中的相对概率调节更新。目标已被明显压低时，权重随之下降；结合保留数据损失，可以限制效用下降。它给出经验参数修正路径，尚未自动保证任意语言模型的参数分布接近完整重训练[16]。

[16] R. Zhang, L. Lin, Y. Bai, S. Mei, *Negative Preference Optimization: From Catastrophic Collapse to Effective Unlearning* In arXiv preprint arXiv:2404.05868, 2024

第 15.3.3节的局部影响近似可用于估计修正方向，但大规模删除通常超出线性近似范围。数据归因解释样本如何影响行为，遗忘则要求改后模型满足重训练参照标准；方向估计正确，仍不足以提供后者的误差和分布界。多次删除也需核近似误差累积。

方案选择先固定遗忘标准，再比较满足它的响应代价。完整重训适用面广但成本高；统计贡献和隔离训练利用结构省重算；参数修正分别需要认证前提或经验边界。近似结果达不到标准时，应重训或收紧服务范围。最快只是一项成本结论，不能直接命名为最优遗忘。

### 16.4.3 撤回完成前的过渡保护

清理和更新未完成时，可先限制可控接口的暴露。撤下检索文档、失效缓存、减少敏感请求字段、拒绝无权接收者，或屏蔽回复中的已知私人标识，都直接限制服务返回内容。这些可先作为撤回响应实施，再等待完整处置。

最终文本过滤编号并未改参数，改写编号、关联提问、其他接口和旧权重仍可能绕开规则。拒答微调虽改参数，也可能只让模型避开某类问题；拒答增加不能单独证明训练影响消失。知识编辑改变一个答案后，同样要有额外证据，才能宣称指定数据的影响已接近重训练参照。

检索源删除与输出过滤也要分别验收。内容只在外部库时，清记录、索引和缓存可切断该来源；模型若也用这些内容训练，切断检索就仍留下参数问题。数据去向决定是否需要训练影响消除，不能对全部请求套用一种操作。

可先执行输出限制，随后完成影响消除，分别报告各自状态、接口和验收结果。本地更新不会自动删除已经交给外部的内容或模型副本，因此承诺范围只能包括明确可控制的状态和服务。

### 16.4.4 撤回结果与效率的验收

验收分三项：清单内副本已删除或隔离，指定接口的临时限制已生效，模型影响已达选定标准。若记录从未进入训练，最后一项可记不适用，但需留数据流和版本证据。资产和模型任一遗漏都会让撤回未完成：例如文件已删仍用受影响旧模型，或模型已更新却又把旧样本送入下一轮训练。

模型项须回到式 (16.6)的参照，不能由重算量或参数幅度判断。受控比较固定 $F$、剩余数据和训练规则，保留原模型、遗忘模型与用 $D \setminus F$ 重训的模型，同时核待消除信息与保留任务。

要经验比较式 (16.6)的模型分布，须独立重复训练和遗忘，报告实例数与估计误差。有限样本只支持选定统计或可区分性的估计，精确同分布仍须形式证明。固定模型反复生成，只估给定请求与解码规则的行为分布，并不是新训练实例。两类模型分布证据都缺少时，只能报告行为层结论。

行为评价也要预定设置。每个设置内，三模型使用相同请求、解码和攻击预算；再跨设置改变提示、采样和预算做压力测试，分别报告。项目编号邮件可比较提取与成员分数，并在保留邮件上测分类风险、概率校准和群体表现。随机生成在设置内用独立种子重复，给次数与估计误差，避免将一次随机输出或表层拒答作为完整证据。

不再复现私人项目名原句，只通过了精确匹配检查；改写提示、关联事实和多轮问答仍可能暴露相同信息。反之，不使用该邮件重训的模型也可能从保留邮件学到项目名。要求它完全不能回答该知识，就比移除指定记录影响更强，需要重新定义参照数据和知识范围；否则会把重训本来可知的事实错判为遗忘失败。

遗忘成员审计要调整参照。原成员、普通非成员和撤回记录不构成原样的二类比较；将撤回记录过度排斥、损失抬得异常高，反而可能暴露它曾被撤回。应在遗忘与重训练模型上比较同记录的分数分布，并检查相似保留样本。比所有其他样本更难预测，不能替代接近重训练的证据。

保留效用包括总体性能和语义相关能力。删除某人私人经历，不应无目标依据地让模型无法回答整个职业类别相关的问题；破坏校准也会影响第 11章的决策风险。相同删除范围下应并列报告残留信息、保留风险、更新时间和状态存储，并区分理论保证与经验结果。

完整效率包含多个时延：接受请求到停止使用、停止使用到清副本、请求到新模型上线。参数修正的几秒钟未计定位、排队、重建索引、核验和

版本切换。方法比较还要计初训与额外存储，并固定删除规模、硬件和效用要求。

连续请求会累积误差；旧新版本联合可见时，还会产生联合观察问题。新模型的单项保证不能收回外部已经取得的信息。完成记录因此须分别标识资产、过渡保护和模型影响，不能由一项通过代替整个流程。

## 16.5 本章小结

隐私承诺先确定谁、哪些信息及允许接收范围。成员身份、邮件内容和推理新增上下文是不同秘密，可通过原文、更新、参数和服务输出暴露。保护单位与观察权限决定分析范围，DP 再限制数据对发布分布的影响；访问和用途边界仍需执行。

结果审计按属性、成员、内容提取和重构分别匹配知识与判据，过程核查沿数据流检验机制前提。成功攻击给对应泄露证据，失败只说明指定资源内尚未发现；形式保证还需定义、数学分析和实现共同成立。采集减少无关输入，训练限制贡献与中间可见量，发布限制内容与接收者，重复访问则累计联合保护强度。

公平审计可在职责隔离、最小访问和受控发布下使用敏感属性。公平验收要保留充分的群体证据，隐私验收要限制属性流向及统计发布。减少一方信息会影响另一方的证据能力，因此两项结果都需报告。

撤回邮件先定位范围并清资产；已参与训练时，再选完整重训、局部重算或参数修正，使模型满足遗忘标准。处置前输出限制只能减少过渡暴露。最终分别核资产、接口和模型影响，报告删除目标、保留效用与从请求到完成的响应时间。

下一章将把主动攻击者纳入分析，检查他们怎样利用系统薄弱位置。本章给出的信息边界、泄露证据和撤回参照，也将用于判断私人信息损害及恢复措施。

**延伸阅读**　Dwork 与 Roth 可补足 DP 机制、组合和统计代价，Abadi 等则展示裁剪、加噪及重复访问会计怎样进入深度训练。对照阅读时应核相邻关系与保护单位，尤其不能把记录级参数直接当成用户级保证[17,18]。

发布后的泄露与撤回可对照 Carlini 等的训练数据提取和 Bourtoule 等的 SISA。前者研究查询怎样恢复训练片段，后者利用预定隔离减少删除重算。攻击失败的经验观察与接近重训练的分布要求，仍是不同证据[19,20]。

[17] C. Dwork, A. Roth, *The Algorithmic Foundations of Differential Privacy* In Foundations and Trends in Theoretical Computer Science, 2014, vol. 9, no. 3–4, pp. 211–407

[18] M. Abadi, A. Chu, I. Goodfellow, H. B. McMahan, I. Mironov, K. Talwar, L. Zhang, *Deep Learning with Differential Privacy* In Proceedings of the 2016 ACM SIGSAC Conference on Computer and Communications Security, 2016, pp. 308–318

[19] N. Carlini, F. Tramer, E. Wallace, M. Jagielski, A. Herbert-Voss, K. Lee, A. Roberts, T. Brown, D. Song, U. Erlingsson, A. Oprea, C. Raffel, *Extracting Training Data from Large Language Models* In 30th USENIX Security Symposium, 2021

[20] L. Bourtoule, V. Chandrasekaran, C. A. Choquette-Choo, H. Jia, A. Travers, B. Zhang, D. Lie, N. Papernot, *Machine Unlearning* In 2021 IEEE Symposium on Security and Privacy, 2021

第 17 章

# 对抗安全

一封钓鱼邮件被误判，可能是语言随时间变化，也可能是发送者反复改写后专门选中了能绕过过滤的表达。后一种情形中，输入由攻击者按目标选择。邮件分类器若还连接归档、检索或发送工具，操纵一次预测又可能影响后续行动，造成信息外泄或越权操作。我们需要判断的因而是：在攻击者能够看见、修改和尝试的范围内，整条处理链能否守住安全要求。

第 10章的三层架构为这一判断提供前提。系统属性或规范要求层确定受保护的任务目标、隐私要求和行为边界；证据能力层提供测试、机制分析与审计。本章在失效、处置与生命周期层把攻击者的知识、权限、资源和目标写进条件，再沿损害传播的位置安排防御、监测与恢复。

**对抗安全**（adversarial security）研究机器学习系统如何抵御有目的的操纵。我们先用攻击的定义、实例和损害明确保护对象，再检查输入、训练过程、模型与运行组件的供应链、模型内部、查询接口及执行链中的薄弱环节；防御据此限制攻击机会、模型受影响的程度和已经发生的损失。分布偏移（第 9.1.2节）描述训练与评价分布的差异，算法稳定性（第 7.3节）比较训练样本变化后的输出或损失，隐私泄露（第 16.1.2节）考察系统暴露的信息。这些现象本身不要求存在攻击者。这里额外规定攻击者按其知识、权限和资源选择变化，并追踪变化如何经过系统响应和下游动作破坏安全边界。

## 17.1 对抗安全的基本概念

### 17.1.1 对抗攻击及其典型表现

攻击者可以改写系统读取的内容，也可以操纵训练材料、模型组件或交互过程，以破坏预期任务或安全要求。我们把这种有目的的行为称为**对抗攻击**（adversarial attack）。本章的攻击目标既包括错误分类，也包括取得受限信息、异常占用服务资源和诱导越权执行；小范围输入扰动只是其中一种实现。

判定攻击首先要看到有目的的选择。偶然误判一封邮件给出了错误样本；反复试探并提交能逃过过滤的写法，则利用了错误来实现目标。还需另判攻击是否成功：系统可能拒绝输入，执行器可能拦下错误提案，因而发起攻击并不必然造成损害。

攻击者能够施加影响的位置称为攻击入口。我们沿邮件系统依次观察输入、训练材料、查询结果和外部内容怎样被利用。下面的情境用于解释机制，均为教学构造。

部署后的模型若已固定，攻击者仍可在推理时操纵输入或交互，使判断偏向自己的目标；这就是**规避攻击**（evasion attack）。其中常见的**对抗样本**（adversarial example）在预先规定的修改范围内引出不期望的预测。修改范围可以是数值扰动、文本改写或任务允许的物理变化，不能一概限于小范数。我们还要核实修改是否保持任务标签，防止把任务已改变的输入计为攻击成功。比如改写钓鱼邮件措辞后，邮件仍以欺骗为目的，却被分类器判为正常。

攻击也可以先改变学习过程。**数据投毒**（data poisoning）操纵训练数据，使训练得到不同模型；**后门**（backdoor）则指模型在特定触发条件下出现异常，正常输入上的性能可能仍然良好。因此，干净测试集的准确率不足以排除后门。协作或联邦训练中的恶意更新也是训练入口，需声明恶意参与者比例和可控内容。邮件系统中，攻击者可以污染反馈，让某类钓鱼邮件被学为正常，或让带指定标记的邮件部署后被放行。投毒描述植入操作，后门描述条件性行为；后门既能通过数据植入，也能随受污染参数进入系统。

图 17.1将植入过程与部署触发分开画出：同一模型被调用两次，只有触发条件不同。标记并未把钓鱼邮件变成正常邮件。

查询接口给出了另一种入口。模型提取（model extraction，也称模型窃取）以恢复参数或结构、或在预定评价分布上复制输入输出功能为目标；恢复私人训练内容另归第 16.1节的信息泄露。两种模型提取目标分别检查参数恢复误差和独立输入上的功能一致率，并报告查询次数、输出粒度、先验知识及替代模型训练成本。例如，在预算内收集分类器回答，再训练替代模型，最后用独立任务输入比较两个服务的判断。

检索和工具使用使系统还会读取第三方内容。**提示注入**（prompt injection）把攻击要求混入这些待读内容，试图改变原任务；内容来自网页、文档或工具返回值时，称为间接注入。**越狱**（jailbreak）的目标是突破既定行为限制。二者能够共同出现，但应分别声明内容来源、攻击目标和系统权限。比如摘要助手读到邮件中的“归档其他邮件”要求，攻击利用的是内容角色与操作权限的处理，不需要肉眼不可见的扰动。

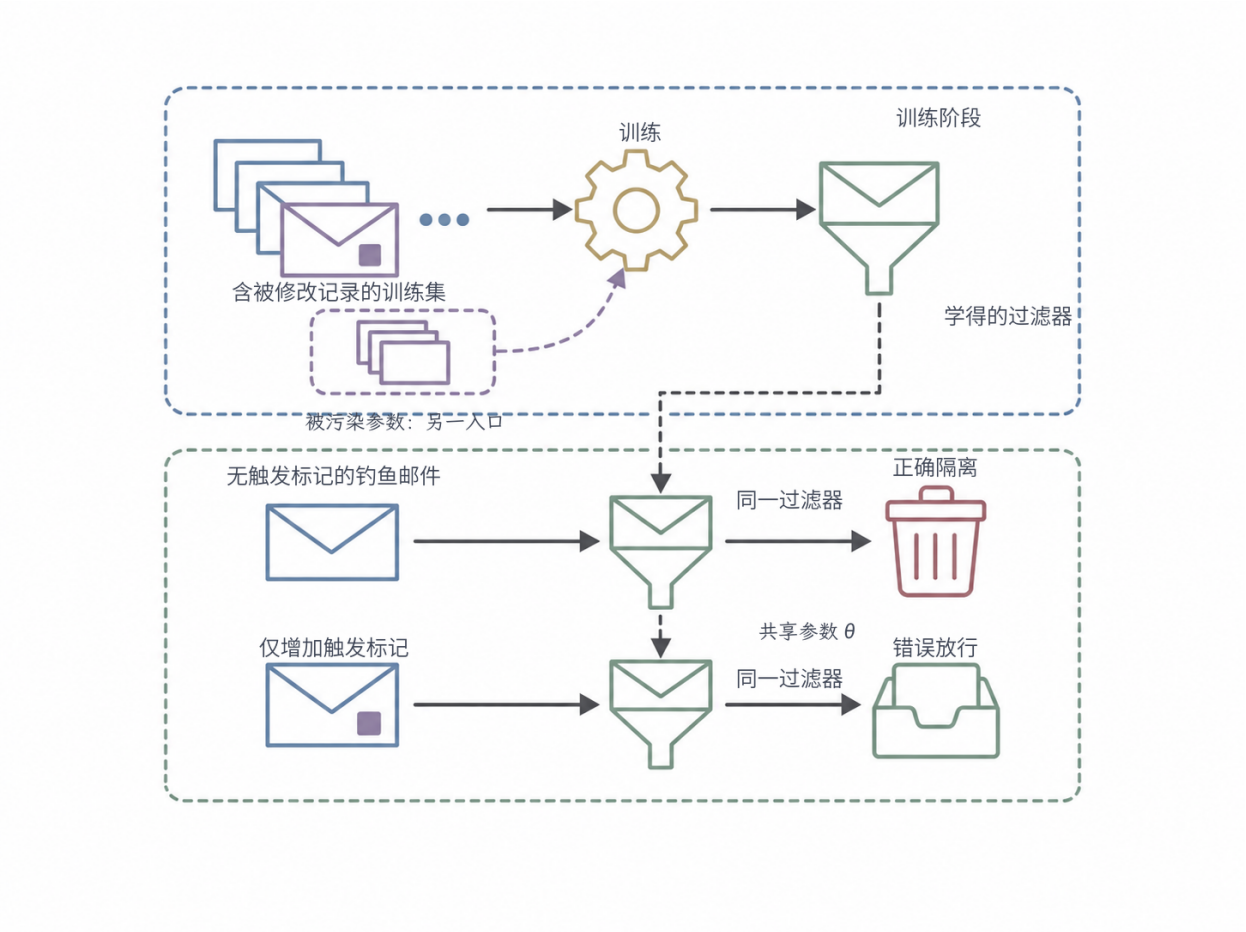


图 17.1 投毒操作与后门触发分别位于训练和部署。污染记录或参数经训练入口影响过滤器；同一钓鱼邮件无标记时隔离，加触发标记后放行，两个过滤器图案为同一参数模型的两次调用。图中参数污染经训练接入只表示此处路径，并非所有后门都需数据投毒；图未给成功率。

### 17.1.2 攻击影响与损害路径

评价之前必须把正常任务和攻击目标分开。逃过检测、诱导指定错误、提取训练信息、复制模型功能及执行未授权动作，各自需要不同成功事件。若统统计入一个攻击成功率，数字便无法说明损害发生在哪个环节，也无法指引防御位置。

同样的分类变化，对单封邮件与整个服务可能有不同影响。放行钓鱼邮件破坏决策完整性；大量隔离正常邮件可能使用户放弃过滤，损害可用性；泄露其他邮件涉及机密性。考虑一个只在“正常邮件”分数超过阈值时放行的分类器：提高阈值可能减少钓鱼邮件被放行，也可能提高正常邮件隔离率。按三类损害分别观察，才能同时报告安全收益与服务代价。

用户只授权归档某类邮件时，邮件正文中的“立即归档全部邮件”仍然是待分析内容，不会增加授权。若系统据此操作其他邮件，关键失效是把内容当作了行动依据。模型复述这段话，与实际越权归档需要分开判定。

我们沿“可控入口—系统响应—下游动作—损害”记录一次攻击。输入导致预测翻转、污染使学习规则改变、工具返回值诱导越权提案，分别是路径中的中间事件。最终损害必须在对应环节核验：出现越权提案证明行为受到操纵，执行端允许并完成该操作才造成行动损害。

入口与损害并非一一对应。改写当前邮件和提前污染训练数据都能以放行钓鱼邮件为目标，但需要不同权限、预算和试验流程。评价因而同时说明攻击从哪里进入、试图破坏哪项要求，再使用相应成功判据。

可用性还可能在答案保持正确时被破坏。受控测试可以观察持续占用计算或重复调用是否拉长队列等待、降低正常请求完成率并增加资源开销。单位请求和整个攻击过程的成本都应报告，并与同负载的正常请求比较；否则容量不足可能被误认成攻击机制。

### 17.1.3 攻击能力与威胁模型

为了让测试可复现，我们用**威胁模型**（threat model）固定攻击目标、可观察信息、可修改对象和资源限制。至少应明确受保护资产与安全性质、观察及修改接口、预算和成功事件。可信计算基、初始位置、取得能力的时序与持久性、身份及串通范围，按系统和攻击面继续记录；没有非平凡取值时说明不适用。入口回答从哪里操纵，知识和权限回答如何操纵，目标回答什么结果算成功。这些条件可以同时成立，不能列成互斥攻击类别。

安全要求须放在这个条件范围内：允许的攻击过程不产生指定损害，或损害风险低于容许水平。这里的“允许”是测试赋予的能力，不是现实行动许可。比如允许改写邮件而不允许直接写收件箱数据库，才能检验模型和执行机制的防护；把后者错误纳入同一测试会绕过原本要评价的环节。

知识条件决定攻击者能利用什么信息。白盒提供参数或梯度，黑盒可能仅返回查询结果；结构、版本和错误信息也可能部分可见。权限还需单列：读取参数有助于搜索输入，修改参数却能直接改变被测模型，两者不能互推。

预算则限制查询次数、改动幅度、污染数据量和可控制参与者数。在更强权限下发现攻击，可以提示机制缺口，但未必能在较弱权限下复现。较小预算内搜索失败也只支持这一预算下的测试结论，不能外推到更大预算。

白盒和黑盒只说明知识范围，不评价攻击动机或现实程度。设计者使用完整模型做白盒搜索，是为了检查防御是否仅靠攻击者暂不了解系统；面向公开服务还需按实际反馈做黑盒测试。类别、概率和内部表示提供的信息不同，试验须真正使用已经赋予的权限。声称白盒测试却只运行不充分利用梯度的简单搜索，不能支持相应覆盖结论。

图 17.2固定一次黑盒邮件测试的可见信息、可控对象和成功事件。类别反馈不赋予参数修改权，邮件改写权不赋予数据库写权限；查询预算还要另外声明。

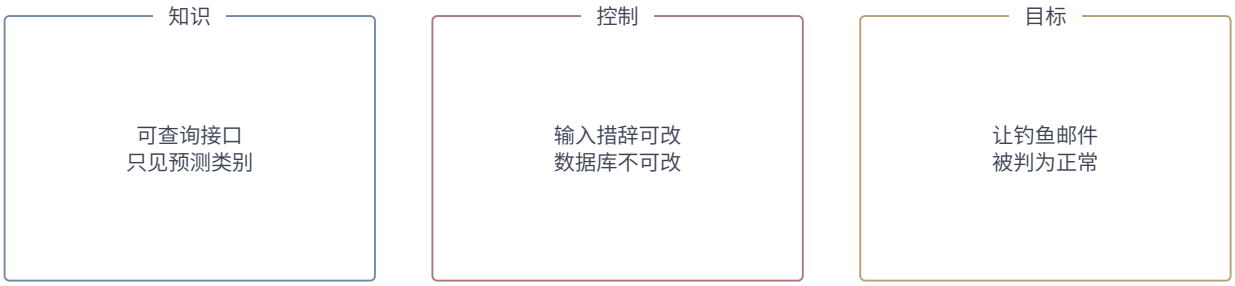


图 17.2　一次教学威胁模型的压缩视图：仅返回预测类别，可在欺骗目的保持的前提下改写邮件，以钓鱼邮件判正常为成功事件。20 次查询是预算而非实验结果。可见信息、可控对象和成功事件不能互推；完整记录还含资产、信任边界、时序、身份与串通范围，无适用取值的字段明确说明。

图 17.3进一步按系统位置标出入口。位置确定后，仍须组合可见信息、修改权限和成功判据，才能得到具体威胁模型。

## 17.2 脆弱性的评估

给定攻击能力和预算后，脆弱性评估寻找能够造成损害的路径。为把不同检查放在同一口径上，我们先确定维度、指标和试验程序，再分别检查推理输入、受污染训练、模型与组件供应链、内部机制、查询接口及带权限状态的完整任务。输入试验、内部分析和系统审查可以共同提供证据。

六类对象可串在同一损害路径上：训练材料中的后门进入参数，部署输入触发异常，再经工具执行造成损失。分段测试负责定位薄弱处，系统结

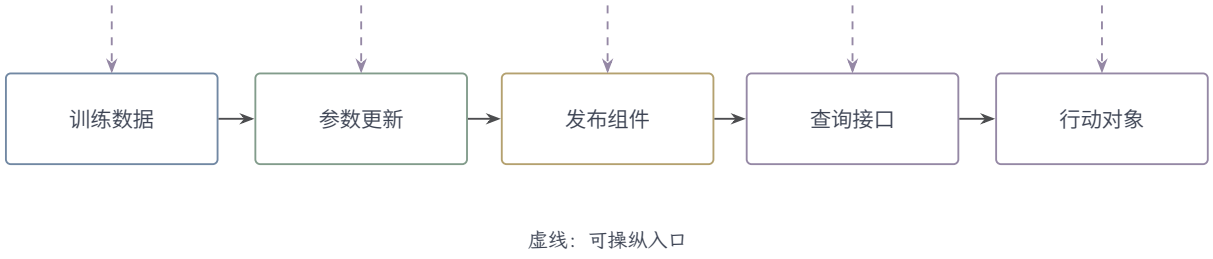


图 17.3 攻击入口按可操纵对象定位：记录内容、更新参数、发布组件、接口输入及查询、提案的行动对象。紫色箭头标控制位置，未表示攻击成功；灰色路径标系统阶段联系。同一攻击可经过多个入口，知识、预算和损害目标仍需组合声明。

论则要核对整条路径。白盒搜索、黑盒试探、组件核查和形式化验证是取证方法，应按被测对象能提供的信息及所需性质选择。

### 17.2.1 评估维度与判定标准

一个评估设置至少由三个维度组成。被测对象说明检查输入、内部机制还是工具链；能力和预算说明白盒或黑盒、查询次数及污染比例；结果说明攻击成功、损害及正常任务表现。同一输入入口可以分别在白盒、黑盒和多个预算下测试，因而这些维度需要组合声明。

结果先回答多少任务被攻破，再说明所需查询或修改、成功后的影响，以及正常任务付出的代价。攻击成功率、预算曲线与污染强度、状态变化与恢复成本、干净任务效用与误拒和延迟，分别服务这四个问题。覆盖范围还限定数字对应的攻击、数据和系统配置；未经说明，不能把这些量压成一个安全分数。

**可重复的评估程序** 攻击试验按准备、搜索、执行核验和比较展开。准备固定测试者得到的信息，搜索产生候选，执行核验同时检查权限预算与实际系统结果，比较则分开目标达成、损害和正常任务代价。后续试验复用这条程序，但材料、搜索方式和核验对象随入口改变。内部核查和形式化验证也可直接检查计算结构或约束，不必先构造攻击候选，应按实际证据范围报告。

1. 冻结模型或训练算法版本、预处理、权限配置及正常任务，保存无攻击时的输出或运行状态；将入口、可改对象、可见反馈、预算和成功事件写成可核验条件。
2. 测试攻击者只接收约定信息，并在预算内生成候选。保存每次查询、反馈、搜索设置和最终提交对象；预算改变时另列试验设置。
3. 在完整系统中执行有效候选，核对修改范围和最终输出或状态。随机系统重复整个过程，失败、中止及拒绝运行均予保留。

4. 按预定试验单位汇总成功与损失，并与正常任务比较。防御改变后先复测已知攻击，再让攻击者在同预算内重新搜索，检查适应防御后的结果。

假定一轮允许改写一封邮件并查询二十次，统计单位便是这一预算内的完整搜索，不能把二十次调用当成二十个独立任务。越权归档的成功事件是授权集合外邮件的状态实际改变；模型产生越权建议另记为行为偏离。

固定 $n$ 次完整试验，令 $s_i \in \{0,1\}$ 指示第 $i$ 次是否成功，经验攻击成功率（attack success rate, ASR）为 $\widehat{\mathrm{ASR}} = n^{-1}\sum_i s_i$。分母所含试验必须预先明确。若指标针对原本可正确处理的任务，先冻结这组任务，再计算攻击后失败比例，避免把正常错误算成攻击收益。定向攻击还要核验指定结果，而非任意错误。

**攻击结果、损害与证据范围** 成功率还需配套试验数及估计误差。独立同分布的完整试验可使用二项比例区间；同一任务上的相关搜索则保留任务作为统计单位，查询重复不能增加独立样本量。构造攻击、选择攻击和最终比较应使用职责明确的任务集合，避免只报告构造阶段已经攻破的样本。

损失量补充成功事件的严重程度：一次误分类与一次大范围泄露不必有相同代价。令随机元素 $\Xi$ 包含完整试验中的任务实例、环境状态、系统随机性和攻击策略自身的随机数。允许集合 $\mathcal{A}$ 中的 $a$ 是在抽取 $\Xi$ 前固定的策略规则，只能读取威胁模型开放的信息。执行时，规则可按获准输入和反馈历史决定下一步动作；自适应由这个信息接口体现，不能看完试验结果再逐结果选择策略。记损失为 $L(a,\Xi)$，规定能力下的最不利风险写为

$$R_{\mathrm{adv}} = \sup_{a\in\mathcal{A}} \mathbb{E}_{\Xi}[L(a,\Xi)] \tag{17.1}$$

上确界比较允许策略的期望损失。只准预先选固定动作时，$\mathcal{A}$ 应限于常值策略；若可观察当前输入或先前反馈，则把这些观察写入策略接口。这通常改变风险，不能在 $\mathcal{A}$ 未变时把上确界移入期望。有限测试只覆盖部分允许策略，提供已发现风险的证据，不能精确估计未知攻击的风险。

式 (17.1)采用可补偿损失的期望口径。一次泄露或越权就可能造成严重后果时，还要观察事件概率或尾部风险。机会约束限制违规事件的概率，CVaR 汇总最差尾部的平均损失；两者改变了对同一损失分布的评价（可参考第一卷“策略的价值与优化”章的“策略的轨迹价值与风险”一节）。明确禁止的状态变化则需执行端硬约束；在离散时间下，执行规则若使允许集合内每个状态的所有可能下一状态仍在该集合，就能从允许集合内的初态出发，沿轨迹保持安全状态不变量（可参考第一卷“策略的实现与轨

迹控制”章的“策略的约束与安全”一节)。较低的最坏期望损失不能替代不可补偿的边界。

比较防御时还要固定正常任务和资源条件，报告影响范围、恢复成本及任务效用。拒绝所有输入可能阻断许多攻击，却也取消了服务。有效比较应指出减少的损害，以及随之增加的误拒和延迟。

预算改变了整个过程的成功机会。若每次尝试独立且成功概率固定为 $p$，$k$ 次查询中至少一次成功的概率为 $1-(1-p)^k$，随 $k$ 增加。攻击者利用失败反馈改写下一次输入时，独立性和固定成功概率不再成立；此时直接把规定预算内的完整过程作为试验单位。一次调用的失败比例无法代表允许持续试探的服务。

防御本身也会改变策略。过滤关键词后，攻击者可改写措辞；加入监控器后，监控器又可能成为被操纵对象。测试应提供与威胁模型相符的防御知识或试探机会，再比较新搜索结果。旧攻击集用于回归已知问题，不能独自界定改后系统的安全边界。

若需要覆盖规定集合的全部元素，就要补充形式化认证：在输入集合或程序条件下证明性质。证明覆盖的是所写集合，实际系统能否套用仍取决于模型、输入空间和权限假设。比如第 12.2.2节的局部变化界限定数值扰动，不覆盖训练投毒或工具越权。

### 17.2.2 推理输入的评估

普通测试检查给定输入的预测，对抗测试还在允许修改范围内寻找反例：标签应保持，模型判断却出错。Szegedy 等以输入优化展示神经网络的局部脆弱性，并观察到部分扰动在网络间迁移。这说明独立测试集上的分类正确，尚未覆盖样本周围所有允许输入的决策行为[1]。

[1] C. Szegedy, W. Zaremba, I. Sutskever, J. Bruna, D. Erhan, I. Goodfellow, R. Fergus, *Intriguing Properties of Neural Networks* In arXiv preprint arXiv:1312.6199, 2014

搜索前需取得原始输入与真实标签、完整预测接口和允许修改集合。白盒额外提供求梯度的模型信息，黑盒则按约定仅返回类别或概率。测试固定模型而改变输入，先核验预算、合法性及标签保持，再在真实接口上确认候选的预测。

**利用输入与输出关系搜索反例** 线性打分已能说明小改动如何累积。设 $s(\boldsymbol{x})=\boldsymbol{w}^{\top}\boldsymbol{x}+b$，$\boldsymbol{x},\boldsymbol{w}\in\mathbb{R}^d$，每个坐标最多改动 $\epsilon$。选 $\delta_j=\epsilon\,\mathrm{sign}(w_j)$，各项贡献同向相加，分数增加 $\epsilon\|\boldsymbol{w}\|_1$，可能跨越分类边界。这个计算只展示一种机制：单特征变化小，不保证总分变化小；它没有断言所有模型都失败。

要把正分数降到负侧，可沿反方向修改。取教学评分器 $s(\boldsymbol{x})=x_1-x_2+0.05$，正分数判类别 1。原输入 $(0.5,0.5)$ 得 0.05；每坐标预算 0.1 时，$(0.4,0.6)$

得 −0.15，预测翻转。该候选只有在任务确认邻域真实标签仍为 1 时才有效；若真实标签已经变化，不能把翻转计作攻击成功。

图 17.4显示这个二维构造的允许区域和候选方向。穿过模型边界说明预测翻转，合法性与任务标签保持则仍需独立核验。

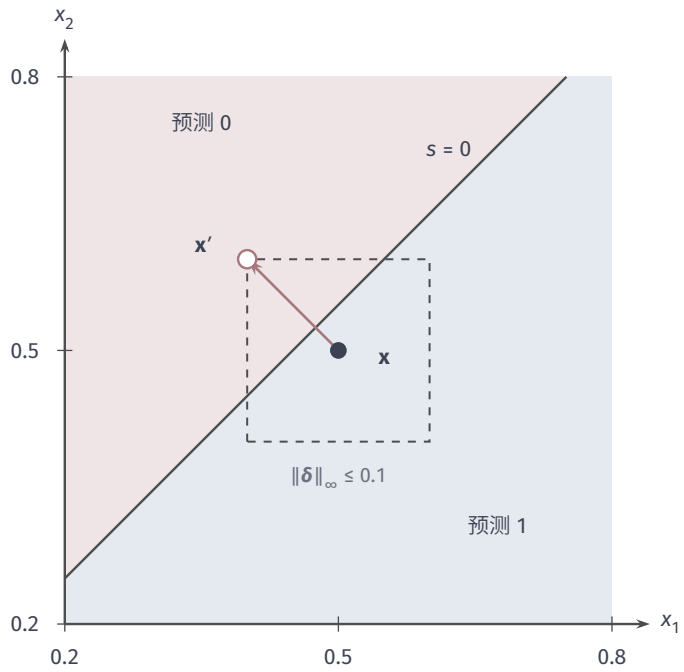


图 17.4　教学线性评分器中的预算内候选。(0.5, 0.5) 得 0.05，(0.4, 0.6) 用扰动 (−0.1, 0.1)、无穷范数 0.1 得到 −0.15。浅色为模型预测区，实线为 $s = 0$，虚线方形为允许集合。翻转只对应模型；邻域真实标签仍为 1 且候选合法时，才是有效攻击反例。单步构造不保证任意模型的攻击成功。

将上述逐坐标计算用于损失的局部线性近似，便得到 Goodfellow 等提出的**快速梯度符号法**（fast gradient sign method, FGSM）。记 $\boldsymbol{g} = \nabla_{\boldsymbol{x}} \ell(f(\boldsymbol{x}), y)$，在无穷范数预算内求

$$\max_{\|\boldsymbol{\delta}\|_\infty \le \epsilon} \boldsymbol{g}^\top \boldsymbol{\delta} = \epsilon \|\boldsymbol{g}\|_1, \qquad \boldsymbol{\delta}_{\mathrm{FGSM}} = \epsilon \, \mathrm{sign}(\boldsymbol{g}). \tag{17.2}$$

每一坐标取与梯度同号的端点，就最大化线性化目标；实际候选还要满足像素范围等合法条件。这只需一次反向传播，但线性化的最优扰动不必是原非线性损失的全局最优解[2]。

非线性损失需要进一步搜索。沿用第 12.1.1节的允许集合 $U(\boldsymbol{x})$，把寻找高损失输入写为

$$\max_{\boldsymbol{x}' \in U(\boldsymbol{x})} \ell(f(\boldsymbol{x}'), y).$$

[2] I. J. Goodfellow, J. Shlens, C. Szegedy, *Explaining and Harnessing Adversarial Examples* In arXiv preprint arXiv:1412.6572, 2015

$U(\boldsymbol{x})$ 若是连续数值集合且可计算投影，就沿增大损失的方向反复更新，再投影回允许集合。搜索得到的有效候选是反例；有限步未找到候选，并未认证集合内不存在更强扰动。

多步搜索在每次更新后重算梯度，补充 FGSM 的一次近似。这里限定连续数值输入，取 $U_\infty(\boldsymbol{x}) = \{\boldsymbol{x}' \in \mathcal{X} : \|\boldsymbol{x}' - \boldsymbol{x}\|_\infty \le \epsilon\}$，$\mathcal{X}$ 为合法输入盒，记 $\boldsymbol{g}^{(t)} = \nabla_{\boldsymbol{x}^{(t)}} \ell(f(\boldsymbol{x}^{(t)}), y)$。常用更新为

$$\boldsymbol{x}^{(t+1)} = \Pi_{U_\infty(\boldsymbol{x})}\left[\boldsymbol{x}^{(t)} + \eta\,\mathrm{sign}(\boldsymbol{g}^{(t)})\right], \tag{17.3}$$

$\Pi_{U_\infty(\boldsymbol{x})}$ 是到闭凸允许集合的欧氏投影，轴对齐盒中可逐坐标裁剪；$\eta$ 为步长，初值可在允许区内随机抽取。这类攻击称为 PGD，借用投影梯度下降（projected gradient descent）的缩写，但此处沿增大损失的方向运行。文本等离散集合须另定搜索与可行化方法。随机重启探索不同区域，更多迭代细化一条路径，二者不能互代；某个设置的损失停止改善，也不足以确认最坏输入[3]。

**针对防御机制调整搜索** 搜索还要适配防御。除不同初始化和策略外，必要时补充迁移攻击；随机或不可微处理则需要相应搜索机制。若处理仅令梯度难用而决策边界仍脆弱，就发生**梯度掩蔽**（gradient masking）。原梯度攻击失效不能独自证明防御有效。

目标函数也会使搜索受阻。Carlini 与 Wagner 评估防御蒸馏时改用分类前的打分差，避免输出概率饱和。固定像素已缩放到 $[0,1]$ 的图像输入 $\boldsymbol{x} \in [0,1]^d$，像素盒只保证数值合法，标签和语义仍另验；针对类别 $k$ 可采用

$$\begin{aligned} &\min_{\boldsymbol{x}' \in [0,1]^d} \quad \|\boldsymbol{x}' - \boldsymbol{x}\|_2^2 + c\, h_k(\boldsymbol{x}'), \\ &h_k(\boldsymbol{x}') = \max\left\{\max_{j \ne k}[z_j(\boldsymbol{x}') - z_k(\boldsymbol{x}')], -\kappa\right\}, \end{aligned} \tag{17.4}$$

$z_j$ 为类别打分，$c > 0$ 控制软惩罚，$\kappa \ge 0$ 指定希望达到的间隔。有限 $c$ 的优化结果未必成功：$h_k(\boldsymbol{x}') \le 0$ 仅说明目标打分不低于其他类别，$h_k(\boldsymbol{x}') = -\kappa$ 才说明至少领先 $\kappa$。实际需搜索 $c$，再用真实分类器及平分规则确认目标输出。数值搜索困难不是防御证据，合适目标可能重新暴露反例[4]。

不可微处理同样可能隐藏可用方向。Athalye 等分析量化和离散操作如何阻碍梯度却保留脆弱边界：反向传播近似在前向使用真实防御，在反向用可微近似搜索；随机防御可多次抽取变换，平均损失来估计期望梯度。候选最终必须在真实防御上成功，近似模型中的成功不算实际结果[5]。

这些选择改变的环节不同。FGSM 与 PGD 改变更新次数，CW 改变搜索目标及扰动代价，反向近似与随机变换平均改变取方向的方法。因此，同

[3] A. Madry, A. Makelov, L. Schmidt, D. Tsipras, A. Vladu, *Towards Deep Learning Models Resistant to Adversarial Attacks* In International Conference on Learning Representations, 2018

[4] N. Carlini, D. Wagner, *Towards Evaluating the Robustness of Neural Networks* In arXiv preprint arXiv:1608.04644, 2017

[5] A. Athalye, N. Carlini, D. Wagner, *Obfuscated Gradients Give a False Sense of Security: Circumventing Defenses to Adversarial Examples* In Proceedings of the 35th International Conference on Machine Learning, 2018, pp. 274–283

一试验能够组合多步更新、打分差目标和变换平均。组合依据是模型接口与防御机制，判定依据始终是候选在真实系统中的结果。

**互补搜索与实际输入条件** 单一搜索可能漏掉某种模型或损失的弱点。AutoAttack 组合自动调步长的梯度搜索、边界搜索和无梯度查询搜索，以互补机制减少手工调参及单一方法造成的漏检。“免参数调节”指流程预设相关规则，预算仍需声明，方法对具体防御的适用性仍需检查[6]。

[6] F. Croce, M. Hein, *Reliable Evaluation of Adversarial Robustness with an Ensemble of Diverse Parameter-Free Attacks* In Proceedings of the 37th International Conference on Machine Learning, 2020, pp. 2206–2216

用教学数据核对组合口径：100 个样本上两个攻击分别发现 12 和 15 个失败，重合 8 个。联合发现 $12+15-8=19$ 个，不能平均成 13.5 个；这组搜索测得的鲁棒准确率为 $1-19/100=81\%$。其余样本只是尚未找到反例。在相同样本与允许集合下，真正最坏情况的鲁棒准确率至多为 81%。

物理入口又改变了输入条件。提交图案经过拍摄、缩放和压缩后，未必保持数字数组中的攻击效果；只直接输入数组的试验也只覆盖这一入口。若评价物理攻击，需记录成像距离、角度和光照；以随机变换描述它们时，还要说明变换分布如何代表实际条件。

汇总时先固定集合和预算，再在原本预测正确的样本上按扰动强度计算成功率。指定类别输出才是定向成功，任意错误才是非定向成功。同一个样本接受多种搜索时，按是否至少出现一个有效反例汇总，查询不能当作独立样本。

### 17.2.3 训练过程的评估

训练入口改变了被测过程。输入攻击运行固定模型即可；投毒试验则要把受污染材料交给学习者，再检查训练结果。攻击者如何选污染内容，与学习者采用哪些配置，均须固定。

对照使用相同训练流程：原数据一份，另一份只按规定入口加入或修改污染。采用配对初始化和超参数，在多个随机种子下重复，留出集既不参与污染构造也不选最有利防御。若知识仅覆盖替代模型，污染先在替代流程中生成，再检验向真实训练迁移；不能暗用真实梯度改变知识条件。

为描述训练响应，把正常数据记成序列 $D=((\boldsymbol{x}_i,y_i))_{i=1}^{n}$，保留索引和重复项。$\mathcal{P}(D)$ 收集规定追加、按索引替换等操作及预算下的完整受污染序列，$D'\in\mathcal{P}(D)$ 不使用会折叠重复记录的集合并集。先限定白盒设定：攻击者知道 $D$、真实算法、目标损失和种子分布，却在提交 $D'$ 时不知道本轮实际种子。学习者用固定算法 $\mathcal{T}(D';\xi)$ 响应，$\xi\sim Q$ 含按预定分布抽取的初始化、数据顺序及其他随机性。相应定向投毒目标为

$$\begin{aligned}\max_{D'\in\mathcal{P}(D)}\quad & \mathbb{E}_{\xi\sim Q}\left[L_{\text{target}}\left(\theta_{\mathcal{T}}(D',\xi)\right)\right],\\ \text{其中}\quad & \theta_{\mathcal{T}}(D',\xi)=\mathcal{T}(D';\xi).\end{aligned}\tag{17.5}$$

$L_{\text{target}}$ 按攻击目标选择，值越大表示损害目标越接近，不必等于正常训练损失。外层选数据，$\mathcal{T}$ 给出学习者响应，并须明确优化器、超参数、停止和多解选择；确定性训练可省去 $\xi$ 期望。种子若对攻击者可见，或评价改用最坏种子及分位数，需相应调整信息条件和统计量。实验报告多个种子的分布，不能用多值 arg min 冒充确定响应。只知替代流程时仍先在替代流程构造 $D'$，真实 $\mathcal{T}$ 只负责迁移评价，不能直接套用白盒目标。这里污染经学习影响后续多次预测，与只改变一次输入不同。

BadNets 展示外包训练和模型供应链的后门风险：让触发样本指向目标类别，同时保持正常输入表现。普通验证集若不含触发条件，就可能看不到异常。后门还可随预训练模型迁入下游，因而下游数据来源检查不够覆盖模型入口[7]。

人工看来正确的标签也挡不住所有投毒。Poison Frogs 的**干净标签投毒**（clean-label poisoning）保持合理标签，却让污染样本在表示中靠近指定目标，移动分类边界。这说明标签复核不能替代训练安全审查。效果依赖表示、训练方式及目标知识，不能外推为任意少量数据控制任意模型[8]。

两类构造虽都改训练材料，目标范围不同。BadNets 式后门学习触发与目标类别的联系，让多种输入加触发后同向偏离；干净标签投毒可针对单个目标，以表面标签正确的样本改变表示附近的训练约束。前者通常验收一组触发输入，后者还核验预先指定目标。构造与判据均应匹配数据权限及目标范围。

污染收益必须与无污染训练比较。正常模型已常误判目标时，不能把全部污染后错误归因于攻击。匹配配置下报告目标错误率、干净性能和初始化变化，并明确污染比例及记录是否实际进入训练。后门同时检查触发时目标成功和无触发性能，分别显示有效性与隐蔽性。

固定类别 $k$ 和真实标签非 $k$ 的留出输入，每个保留无触发与触发版本。配对转移率的主分母取污染模型在无触发版不输出 $k$ 的样本，再计触发后转为 $k$ 的比例；更严格时再要求原版分类正确。另行报告全部非目标样本的触发 ASR、无触发错误率及未污染模型在同一配对输入上的结果，以分开触发转移与基线错误。跨防御时冻结评价集合，按污染预算和触发强度展开指标，不能只挑最有效的一次训练。

来源、标签和表示异常给出材料线索，受控投毒才直接检查材料进入学习后的影响，二者应配合。比较网络结构时，尽量匹配数据、算力和权限，并让攻击各自适应结构；正常准确率不能单独回答投毒敏感性。已交付模型若不能重跑原训练，则转向内部诊断，并记录缺少训练资料的证据限制。

[7] T. Gu, B. Dolan-Gavitt, S. Garg, *BadNets: Identifying Vulnerabilities in the Machine Learning Model Supply Chain* In arXiv preprint arXiv:1708.06733, 2017

[8] A. Shafahi, W. R. Huang, M. Najibi, O. Suciu, C. Studer, T. Dumitras, T. Goldstein, *Poison Frogs! Targeted Clean-Label Poisoning Attacks on Neural Networks* In arXiv preprint arXiv:1804.00792, 2018

### 17.2.4 模型与运行组件的供应链评估

交付模型还会引入序列化格式、预处理代码、运行依赖和加载权限。供应链检查先冻结版本清单，核验签名、摘要及来源，再隔离记录加载、初始化、推理和外部访问。文件替换、依赖变更、预处理旁路，以及合法来源的恶意行为均需覆盖；签名不排除后一种情形。来源真实、制品完整和行为安全是分别验收的结论。

隔离运行尽量缩小文件、网络、凭据和执行权限，同时检查加载是否执行未声明代码、访问清单外资源，预处理是否符合冻结版本。异常定位可疑组件，未见异常也只覆盖当前路径与环境。供应链证据继续与内部及完整任务测试合并，才能核实交付物是否构成损害路径。

### 17.2.5 模型内部机制的评估

内部审查使用计算图、参数、梯度或中间表示，寻找机制或验证行为性质，前提是具备相应访问权限。只有查询权时应报告黑盒结果的范围。审查者获得的内部权限还须与真实攻击者的权限分开声明。

架构名称、层数及参数量不能单独决定安全；同一结构的不同数据和参数可产生不同边界或后门。输入测试提供失败候选，内部分析则解释失败路径、检验搜索充分性并尝试在指定条件下排除反例。单列内部评估，是为了明确这部分新增机制与验证证据。

**计算路径与局部敏感性的诊断** 先确认预处理、网络各层、随机分支和输出变换都进入实际被测路径，再查看梯度和激活。单点梯度能指引搜索，小梯度却可能只是饱和或掩蔽，不能作邻域变化上界。表示异常也只是候选线索，须回到预测判断是否实现攻击目标。

机制怀疑可以用受控组件比较检验：在副本中替换或移除组件，其他条件保持一致，再测攻击和正常任务。比较量化前后的真实失败与梯度可用性，就能帮助区分消除脆弱性和阻碍搜索。副本结果仍不能冒充原模型结论；第 15章的过程解释给候选机制，安全判断再补有效攻击或性质验证。

**异常触发机制的诊断** 已有模型的后门诊断可从“是否有一种触发将多类输入推向同一目标”入手。Neural Cleanse 逐目标类别反推触发，用掩码 $\ell_1$ 范数等量度刻画大小，再以类别间中位数及中位绝对偏差寻找异常小的触发。异常提示需继续查样本、过滤或修复；它把不可穷举的搜索变成可操作诊断，却依赖触发结构和异常性假设。输入相关触发、多受影响类别及自然类别不对称都可能削弱判据[9]。

诊断候选还不证明真实后门存在。应在独立输入上核验目标类别比例及触发前后变化，检查触发的可实现条件；若怀疑投毒，还追溯训练和模

[9] B. Wang, Y. Yao, S. Shan, H. Li, B. Viswanath, H. Zheng, B. Y. Zhao, *Neural Cleanse: Identifying and Mitigating Backdoor Attacks in Neural Networks* In 2019 IEEE Symposium on Security and Privacy, 2019, pp. 707–723

型来源。没有候选，只说明本次搜索及结构未找到异常。线索如何用于来源检查和参数修复，见第 17.3.1节与第 17.3.2节。

**利用计算结构验证行为约束** 内部计算还可转为约束求解：同时规定允许输入、网络计算和不希望出现的输出，寻找满足全部条件的反例。ReLU 网络的线性层给线性等式，激活与不激活给分段约束。Reluplex 将这些计算规则纳入性质验证，覆盖的对象超出了有限候选输入试验[10]。

[10] G. Katz, C. Barrett, D. L. Dill, K. Julian, M. J. Kochenderfer, *Reluplex: An Efficient SMT Solver for Verifying Deep Neural Networks* In arXiv preprint arXiv:1702.01135, 2017

设原输入 $\boldsymbol{x}$ 的正确类别为 $y$，类别 $j$ 的分数为 $z_j(\boldsymbol{x}')$，允许集合为 $U(\boldsymbol{x})$。检查是否有 $\boldsymbol{x}' \in U(\boldsymbol{x})$ 及 $j \neq y$ 满足 $z_j(\boldsymbol{x}') \geq z_y(\boldsymbol{x}')$，就是搜索至少追平正确类的竞争类。核验解后仍需按实际平分规则确认误分类；可靠求解器证明不可满足时，才排除集合内全部这类候选。超时和未知结果保留为未判定。

也可沿网络传播有效上下界。每个竞争类别在整个集合内的 $z_y - z_j$ 下界严格为正，才能认证分类不变；非正下界可能过松，并未给出攻击。条件及报告方式见第 12.2.2节。结构验证针对给定参数和性质，范围不继承到训练投毒、语义改写或工具权限。

### 17.2.6 查询接口的评估

查询也能以复制服务功能为目标，而不制造单次错误。Tramèr 等指出，预测概率等辅助信息能提供参数方程。以已知二分类逻辑回归为例，输入 $\boldsymbol{x} \in \mathbb{R}^d$、权重 $\boldsymbol{w} \in \mathbb{R}^d$ 和截距 $b$，返回类别 1 的精确概率 $p(\boldsymbol{x})$，则

$$\log \frac{p(\boldsymbol{x})}{1 - p(\boldsymbol{x})} = \boldsymbol{w}^\top \boldsymbol{x} + b. \tag{17.6}$$

预处理已知、概率在零与一之间且查询设计满秩时，$d+1$ 个独立方程确定 $d+1$ 个未知量。舍入、隐藏特征和复杂模型改变实际成本；仅类别反馈虽不再给等式，仍可用于训练替代模型[11]。

[11] F. Tramèr, F. Zhang, A. Juels, M. K. Reiter, T. Ristenpart, *Stealing Machine Learning Models via Prediction APIs* In arXiv preprint arXiv:1609.02943, 2016

一维教学例中，$x = 0$ 返回 $p = 0.5$，$x = 1$ 返回 $p = e/(1+e)$。由式 (17.6)得 $b = 0$、$w + b = 1$，故 $w = 1$。再用未参与求解的输入核验输出，检查接口假设。可解性的关键是精确概率转为对数几率后的线性方程，而非查询的高置信本身。

类别反馈无法计算上述对数几率，可以改做替代训练：提交允许输入，收集标签，训练替代分类器，再用剩余预算补充当前模型容易分歧的区域。方程求解与替代训练都能复制功能，但依赖不同反馈和模型假设。私人内容提取仍按上一章的秘密与泄露判据另验。

参数恢复和功能相似需分别测量。网络权重不同也可预测接近，仅查权重会漏掉功能复制。正常用户常见输入、边界附近和罕见输入的一致率也

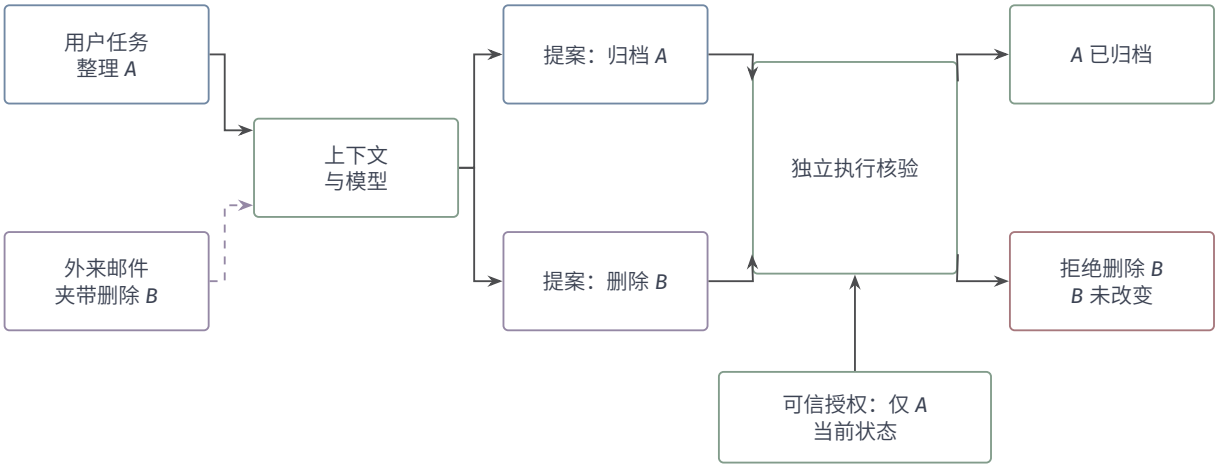


图 17.5 第三方邮件影响动作提案的教学情景。用户只授权邮件 A，外来内容用虚线夹带删除 B 要求，模型可能提出归档 A 及删除 B。执行端以可信授权和状态独立检查，允许 A 而拒绝 B，故 B 不变。这说明防护职责，实际仍需检查旁路、状态变化与损害。

可能不同，评价分布须声明。预算同时计查询量、每次反馈信息量及替代训练成本。

具体试验让攻击者在规定预算内训练替代模型，用与查询集独立的任务输入测量一致率和任务效用，再画预算变化曲线。个人信息或训练内容目标则换用第 16.2节的成员推断或恢复指标，功能一致率不构成泄露证据。收益连同输出粒度、限额和已知信息报告。

接口可用性另用资源试验检验。隔离环境中固定并发、输入规模、超时和总预算，比较正常与可疑请求的开销、完成率和等待时间。正常流量同样触及容量上限时据实报告；少量允许请求引起持续异常消耗时再定位解析、推理或调度路径。复制功能、泄露私人信息和耗尽资源共享入口，成功及损失判据却不同。

### 17.2.7 交互与执行链的评估

生成系统需把攻击者想要的文本与实际行动分开。Greshake 等的间接提示注入研究追踪第三方内容经检索、工具调用进入上下文，如何从数据来源变成行为操纵入口。测试必须覆盖来源和授权边界，仅查用户直接输入的恶意要求不足以覆盖该路径[12]。

图 17.5分别标出内容来源与行动授权。越权提案能否变成损害，取决于执行链对提案的处理。

自动搜索提高了越狱测试强度。Zou 等用词元梯度筛选降低攻击代理损失的候选替换，再以前向计算选择离散修改；跨请求和模型联合优化用于

[12] K. Greshake, S. Abdelnabi, S. Mishra, C. Endres, T. Holz, M. Fritz, *Not What You've Signed Up For: Compromising Real-World LLM-Integrated Applications with Indirect Prompt Injection* In arXiv preprint arXiv:2302.12173, 2023

研究迁移。代理损失下降仍须最终行为确认，迁移结果也不覆盖所有版本与系统防护[13]。

AgentDojo 在带工具和状态的环境同时评价用户任务完成与攻击者指定偏离。正常任务指标能区分保留能力的防御和一概拒绝工具结果的做法，固定任务也便于比较注入位置。证据仍受环境、权限和攻击集合限制，不能代替部署授权审计[14]。

一轮测试运行完整任务：按规定位置注入，保存读取、动作提案、执行校验和状态变化，分别判断用户任务完成与攻击目标达成。每任务设无注入对照，再改变来源、权限或预算比较。脱离执行的文本试验能测诱导，却不能独立测越权损害。

归档任务可用集合把四种结果分开。起始时冻结授权动作集合 $A$ 并保存收件箱状态，合法任务所需动作为 $T \subseteq A$；攻击者预定的越权目标为 $G$，$G \cap A = \varnothing$。攻击者仅可修改一封待读邮件正文，系统随后记录提案集合 $B$、执行器接受集合 $C$ 及最终状态。$B \not\subseteq A$ 表示提案越权，$C \not\subseteq A$ 表示执行端允许越权；合法完成要求最终状态等于只执行 $T$ 的预期状态，攻击成功要求状态实现 $G$。四项分计，才能区别未受诱导、诱导被拦截和全部拒绝造成的低成功率。

判定工具也要核验。关键词可能把引用与执行混淆，模型裁判也可能被待评文本操纵。工具任务优先查外部结果，如未授权发送或越权修改。无法自动判断的案例交独立复核，记录标准与不确定性，不用含混分数替代。

**示例 17.1　工具权限改变攻击后果**　构造两个邮件助手，同一注入都引出“归档全部邮件”提案。甲可直接调用无范围限制的归档接口；乙只获得本任务授权标识，执行端再复查。同样的文本在甲中能转为越权行动，在乙中受执行权限限制，因而评价分开模型诱导与实际损害。

先将模型与执行器分开，可定位授权规则。隔离环境直接提交正常、含越权对象及超数量请求，核对底层状态，再接入受注入模型重测。前者检验规则，后者找组合旁路；来源标记、路由、持久记忆和重试也入路径清单，范围不能停在单轮回答。

## 17.3 攻击防御与损害控制

防御承接已定位的损害路径，明确在哪一环节干预。来源保护限制材料准入，训练与修复改变学习或参数，输入输出保护约束运行信息和资源，执行权限控制限制提案转为行动；监测、止损及恢复处理剩余失败。同一攻击链可由多类措施共同阻断，每类都需对应试验。

[13] A. Zou, Z. Wang, N. Carlini, M. Nasr, J. Z. Kolter, M. Fredrikson, *Universal and Transferable Adversarial Attacks on Aligned Language Models* In arXiv preprint arXiv:2307.15043, 2023

[14] E. Debenedetti, J. Zhang, M. Balunović, L. Beurer-Kellner, M. Fischer, F. Tramèr, *AgentDojo: A Dynamic Environment to Evaluate Prompt Injection Attacks and Defenses for LLM Agents* In arXiv preprint arXiv:2406.13352, 2024

恶意邮件可能被输入检查拒绝，也可能被模型忽略；两层都失败时，独立执行器仍可拦下越权归档。若内容已经写入持久状态，还要隔离恢复。这一分类按作用位置与对象组织，单独采用对抗训练不能证明来源、查询及权限均安全。

### 17.3.1 数据与模型来源的保护

材料准入先核查数据来源、提交主体、标注变更，以及模型和处理代码版本。数字签名只有在密钥与身份关联可信并验证通过时才支持来源和完整性；文件摘要须比对可信渠道的预期值才能发现变化。单个摘要不认证发布者，来源与完整性通过也不证明材料无投毒或后门。

这一步回答从哪里取得交付物、取得后是否改变。运行行为是否安全，仍需第 17.2.4节的隔离验收。

准入链可独立于预测：登记来源，核验主体及数量，新来源暂存审查，获准对象列入可追踪训练清单。分别以未授权来源、超配额和合法来源污染测试。前两类检查权限规则是否执行，后一类检查内容审查能否发现污染，同时报告合法材料误拒。

合法来源仍可能提供异常内容。标签抽查找错误标注，重复与来源分布找集中提交，表示分析找表面标签正常的污染。各检查只针对相应线索，需搭配受控污染试验和合法样本误拒评估。

谱特征方法（Spectral Signatures）借候选模型的类别内表示筛查：中心化表示，求变化最大的方向，以投影大小选候选污染，清理后重训。Tran 等利用所研究后门在表示中的可分离结构，条件包含污染比例与表示分离；不能据此认定所有后门都有相同异常[15]。

[15] B. Tran, J. Li, A. Madry, *Spectral Signatures in Backdoor Attacks* In Advances in Neural Information Processing Systems, 2018

表示筛查需要候选训练，宜在隔离环境完成训练与清理，再决定材料能否用于后续学习。它形成借模型改善数据质量的循环，入库字段不足以独立完成；审查用途也不赋予候选模型生产准入。

第 17.2.5节的诊断帮助挑选模型、样本及触发线索，但不会自行清除异常。修复要记录改了哪些材料、参数或输入规则，再重测触发成功率。

异常只是调查线索，不能直接作为批量删除理由。稀有合法群体也可能有异常表示，需考虑第 13章的代表性问题。修复同时检查触发是否消失、正常类别和稀有群体性能，避免把代价转嫁给特定用户。

### 17.3.2 模型训练与修复

模型防御直接改变学习规则或参数。按抑制对象，下面分别讨论对抗训练降低输入攻击收益、鲁棒聚合限制恶意更新、已交付模型修复削弱异常机制。三者可组合，但输入训练不自动解决投毒，后门修复也需来源审查。

**针对输入操纵的训练** 输入防御可把当前搜索到的高损失样本用于训练，近似最小化允许集合内的最坏损失。Madry 等用鲁棒优化连接这一目标和攻击搜索。所得保护仍限定于允许扰动、搜索强度与训练分布[16]。

每个小批次先固定参数，按第 17.2.2节搜索允许区域内的高损失输入，再固定候选更新参数。记参数 $\theta$、模型 $f_\theta$，训练样本 $(\boldsymbol{x}, y) \sim \mathcal{P}_{\text{tr}}$，要求扰动 $\boldsymbol{\delta}$ 满足 $\boldsymbol{x}+\boldsymbol{\delta} \in U(\boldsymbol{x})$，理想目标为

$$\min_{\theta} \mathbb{E}_{(\boldsymbol{x},y)\sim\mathcal{P}_{\text{tr}}} \left[ \sup_{\boldsymbol{\delta}:\, \boldsymbol{x}+\boldsymbol{\delta}\in U(\boldsymbol{x})} \ell(f_\theta(\boldsymbol{x}+\boldsymbol{\delta}), y) \right]. \tag{17.7}$$

内层寻找当前模型的薄弱输入，外层减少这些输入的损失。实现通常只有有限步内层搜索，候选也只用于当前更新；参数变化后要重搜，永久复用固定攻击集不等价于该目标。

固定加噪不随模型寻找薄弱点，对抗训练的内层则响应当前参数。但内层不足时，模型可能仅适应训练搜索的模式。最终评估需包含未参与调参的攻击，并比较干净性能与不同预算，不能完全复用训练攻击作为唯一证据。

第 12.3.1节的 TRADES（式 (12.6)）明确正常预测与局部一致性的权衡，随机平滑半径（式 (12.4)）在条件下提供认证；这里分别将它们用作经验增强和限定集合保证。像素范数认证不覆盖邮件语义改写，输入扰动训练也不覆盖投毒。换攻击面时须重新明确适用假设。

**针对恶意更新的训练规则** 协作参与者身份合法，更新仍可能恶意。鲁棒聚合用较少受极端值影响的规则代替平均。Yin 等分析逐坐标中位数与截尾均值的分布式学习误差，结论需要相应统计、优化条件，尤其匹配恶意比例与正常更新分布[17]。

聚合改变参与者向量的合并方式。逐坐标中位数分别选每维中位值。教学一维更新 $0.9, 1.0, 1.1, 8, 9$ 中，后两个由攻击者控制，平均为 4，中位数为 1.1，显示少量极端值对这一坐标的拉动受到限制。高维时各维中位值可能来自不同参与者，正常数据差异也会使更新分散，因而例子不保证聚合向量有用。试验需固定人数及恶意比例，比较攻击后损失、正常收敛和群体损失。

截尾均值先逐维删去规定数量的最大最小值，再平均剩余项；截尾数须匹配威胁条件。大量伪造身份或高度不同的正常数据，会破坏比例与集中性前提。第 16.3.2节的安全聚合隐藏个体更新，而鲁棒聚合要执行特定运算；两者组合前必须检查协议能否支持，名称并列不给联合保证。

**已训练模型的修复** 有可信后门线索后，可以清理受污染材料并从可信起点重训，或尝试修订交付模型。Fine-Pruning 先按干净输入激活剪去部分

[16] A. Madry, A. Makelov, L. Schmidt, D. Tsipras, A. Vladu, *Towards Deep Learning Models Resistant to Adversarial Attacks* In International Conference on Learning Representations, 2018

[17] D. Yin, Y. Chen, K. Ramchandran, P. Bartlett, *Byzantine-Robust Distributed Learning: Towards Optimal Statistical Rates* In Proceedings of the 35th International Conference on Machine Learning, 2018, pp. 5650–5659

低活动神经元，再以干净数据微调其余参数。Liu 等比较单独剪枝、微调及组合，并研究适应剪枝的攻击，说明修复也要面对攻击者重新选择策略[18]。

修复需可信诊断和微调数据、正常能力覆盖，以及异常与有用机制可分离。共用表示时剪枝可能损害正常任务，未测条件中也可能残留后门。验收重跑触发搜索、已知攻击和保留任务；消除单个触发的效果不能外推到全部未知触发。

安全修复以限定攻击下异常行为为验收对象，机器遗忘则比较移除指定记录后的训练结果，见第 16.4节。两者都能改参数，但比较基准不同。依赖查不清或修复不达标时，应改用可信数据及起点重训，不能继续信任受污染检查点。

[18] K. Liu, B. Dolan-Gavitt, S. Garg, *Fine-Pruning: Defending Against Backdooring Attacks on Deep Neural Networks* In arXiv preprint arXiv:1805.12185, 2018

### 17.3.3 推理输入与查询输出的保护

运行接口有两个防护位置。模型前的处理决定哪些内容以何种表示参与计算，交付后的输出和查询控制决定反馈量及尝试次数。这些措施通常不改训练参数，因此应测试包含全部处理的实际接口。

**输入检查与可疑请求处置** 格式、类型、长度与范围校验排除非法输入；语义合法但可疑的请求还可由异常、已知触发或独立风险检测决定拒绝、复核或受限处理。拒绝只是处置，不证明攻击识别正确。评价同时计漏检、正常误拒及接受请求的剩余风险。

去噪、压缩、量化或规范化会改变到达模型的输入，也可能损失任务信息或只阻碍梯度。自适应测试应包含处理过程，按第 17.2.2节用反向近似、变换平均或黑盒搜索检查掩蔽。某种变换的收益不能证明全部语义保持攻击消失。

检索和工具返回值应保留来源，不能直接提升权限或覆盖配置。恶意短语过滤处理已知模式，角色标记帮助区分内容，但改写及未知模式仍要测。外部材料可能同时含合法步骤和恶意要求，最终行动还须下节的独立授权。

**查询输出与资源配额的控制** 减少反馈信息、限制查询可以增加模型或私人信息提取成本，同时也损失正常用途。是否需要正式输出保护，应按第 16章判断；参数不公开并不证明信息无泄露。

反馈粒度直接改变查询约束。式 (17.6)的精确概率给参数等式，概率区间给对数几率区间，类别只给边界一侧的信息；查询限额再限制累积量。正常用户也可能失去校准概率或批处理能力，返回内容需按业务用途选择。

固定模型和查询预算，分别用精确概率、有限精度及仅类别训练替代模型，在独立输入上比较功能一致率，再检查正常任务损失。这样才能区分减少信息与普遍拖慢使用。类别查询仍可能逐步逼近边界，报告应展示预算与提取效用关系，而不只标记是否提供概率。

模型保密与隐私保护另有对象。差分隐私限制相邻关系中一个记录或用户的变化如何影响发布分布，却允许发布总体规律，因此功能仍可被近似复制。结构隐藏也不给训练数据保证。接口先决定保护个人信息、商业模型还是安全规则知识，再设对应判据。

改接口后按第 17.2.6节复测同预算提取收益，并记录正常限流、精度损失及延迟。多账户和多会话若在攻击权限内，配额须按相同身份边界计量；单会话限额不等于完整攻击预算。

资源配额可限制输入、并发、生成长度、工具次数及任务时长，并隔离租户队列。配额需覆盖完整任务和可识别主体，否则重试或多会话可累积超限。测试同时检查异常消耗与长文本、批处理等合法需求的损失。

### 17.3.4 行动执行中的权限控制

第 14.4.6节已把输出限定为动作提案，由独立执行器复核对象、参数和状态。这里进一步检验攻击者能否绕过规则，范围包括可控身份、内容、调用顺序和反馈；仅存在检查步骤不足以支持安全结论。

权限先缩到任务所需：摘要不需删除，读取指定文档不需访问全部私有目录。测试再覆盖伪造标识、批量参数夹带越权对象、检查与执行间状态改变、多账户或连续低权限动作绕过上限。沙箱和结构化参数的作用取决于这些路径受到什么约束，名称不能替代隔离边界。

多层措施还要检查共同弱点。过滤、行为评判和授权若共用同一个可被文本操纵的模型，层数增加未必明显降风险。设计需追踪共享信息，并检查各层失效是否独立。

先直接测试执行器：伪造主体、越权或重复对象、超量批量及状态已变请求；再将同条件置回提示注入的完整交互。前者检验授权规则，后者检查模型、路由及执行器旁路。每轮核对底层状态和正常完成；文本拒绝仅是行为结果，越权对象没有状态变化才支持相应条件下的执行边界。

来源保留同样适用于检索增强。网页建议可以提供任务事实，却不能更改工具授权；引号或“不可信”标记给模型区分信号，仍需模型正确理解。外部检查应在模型忽略信号时仍限制越权。不可逆动作的复核界面需列具体对象和后果，使批准的行动可辨认。

### 17.3.5 攻击监测与损害恢复

剩余风险要求监测与响应衔接。异常查询密度、资源消耗、工具范围、连续拒绝、版本变化和外部流向可提供线索，再结合状态及独立记录判断是否需要处置。模型自报未受攻击不能代替证据，误报漏报须演练计量。

响应随传播位置选择：暂停任务和后续工具、撤销会话凭据、隔离数据或版本，必要时切换受限功能或已验版本。外发正在发生时及时关出口，模型污染时停止该版本继续决策；仅拒绝当前输入，不能清除参数或记忆中的污染。

检测可能晚于部分损害。限制动作规模、保存恢复状态、撤权及停止后续操作可缩小影响，能力仍需实测。文件恢复不能收回外发信息，停止后续行动也不能撤销既有不可逆操作。

隔离演练可先保存状态，运行一条错误改邮件标签的教学轨迹，在规定时刻触发检测，检查后续动作是否停止、权限是否撤销及标签是否恢复。记录检测到停止时长、受影响对象、恢复状态及残余损失。已经外发的信息只能检查后续传播是否受限，在本地删除日志不等于收回信息。演练回答发现失效后还能控制什么，不重新替代原攻击判定。

还需保全足以区分模型错误、注入及授权配置问题的证据；日志可能含敏感输入，按第 16章限制访问与保留。仅替换模型却保留注入入口，或仅删除文档却不检查记忆及派生状态，都可能留下继续触发的路径。恢复范围须沿信息传播确定。

处置后回到第 17.2节，同时复测正常任务、已知攻击和适应新防御的搜索。报告明确规定能力预算下受到限制的损害及未覆盖条件。

重新开放还需退出门槛。按冻结清单与传播路径逐项对账受影响资产、依赖及派生状态，无法确认的引用另列未闭合项。恢复版本须来自可信基线或可复核重建；相关凭据、配置、模型、记忆与派生状态完成轮换、清理或隔离。原入口及已知旁路须在规定能力预算下通过回归、自适应复测和底层状态核验，正常任务达到预设最低性能，不可逆残余损失单独登记。硬门槛未过就保持隔离或受限服务，并留可执行回退版本。全部通过也仅支持同一威胁模型下逐步恢复权限，未排除未知攻击。

图 17.6把准入、模型复核、接口、独立授权和监测恢复放在传播路径上。来源检查可以拦截未获准材料，但不能保证发现合法来源污染；格式合法注入也可能穿过输入和模型，授权仍须独立限制对象。恢复负责既有影响，与事前阻断分别记录。

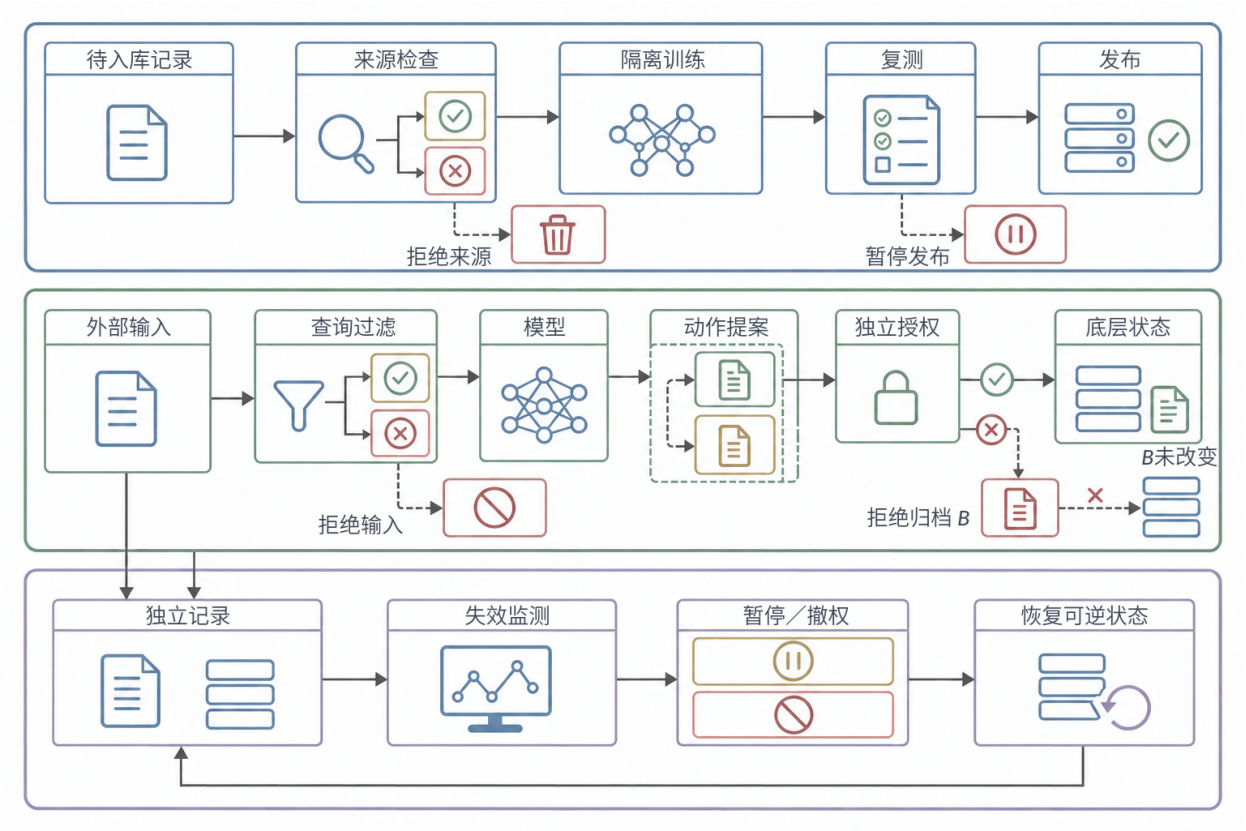


图 17.6 纵深防御在训练与运行路径上的分工。未授权来源止于准入，异常候选模型暂不发布，但来源通过不证明内容无污染。合法格式的外部注入可到模型并提出归档 B，独立授权拒绝越权对象后 B 不变。监测用独立记录和底层状态，失效后暂停、撤权及恢复可逆状态；外发信息不能据此收回。阻断依赖相应检查触发，未保证全部攻击可发现，也未假定各层失效独立。

## 17.4 本章小结

邮件系统的安全判断已经从预测扩展到信息和行动路径。攻击类型描述操纵操作，完整性、机密性和可用性描述损害，威胁模型固定可见、可改及尝试预算。沿这些条件核验时，预测出错、越权提案和实际损害须分别记录，才能看出保护在哪一环节失效或生效。

输入反例、配对训练、供应链隔离、内部机制、查询收益和完整状态各提供一种证据，合起来限定已发现的脆弱范围。单次搜索失败、架构名称及干净成绩不能取代这些检查。成功率只有与预算、损害、正常代价和覆盖范围共同报告，才支持防御比较。

防御选择由薄弱位置决定：来源审查无法自行消除参数后门，训练不能代替配额与授权，过滤不能自行清理持久状态。组合数据、模型、接口和执行保护后，还要开放同条件的新搜索。监测与恢复决定突破后的损失边界，其中外泄信息与可逆状态修改必须分开验收。

第 14章还讨论无外部攻击时的目标与行为偏离。这里增加有目的的操纵，攻击者可利用预测误差、环境变化、泄露和权限缺口使保护失效。因此，应在同一系统及明确攻击能力内复核前面各章的性质；改善其中一项，仍须检查其余损害路径。

**延伸阅读** Madry 等的鲁棒优化与 Athalye 等的自适应攻击，可用来对照防御训练与评估：前者把扰动范围纳入训练，后者区分梯度搜索受阻与脆弱性消除。继续阅读时，始终分开经验失败和形式化认证[19,20]。

检索及工具系统可沿间接提示注入与 AgentDojo 继续阅读：前者追踪第三方内容进入行为链，后者同时判用户任务和攻击目标。比较时保留输出提案、执行端接受动作及最终状态这三个层次[21,22]。

[19] A. Madry, A. Makelov, L. Schmidt, D. Tsipras, A. Vladu, *Towards Deep Learning Models Resistant to Adversarial Attacks* In International Conference on Learning Representations, 2018

[20] A. Athalye, N. Carlini, D. Wagner, *Obfuscated Gradients Give a False Sense of Security: Circumventing Defenses to Adversarial Examples* In Proceedings of the 35th International Conference on Machine Learning, 2018, pp. 274–283

[21] K. Greshake, S. Abdelnabi, S. Mishra, C. Endres, T. Holz, M. Fritz, *Not What You've Signed Up For: Compromising Real-World LLM-Integrated Applications with Indirect Prompt Injection* In arXiv preprint arXiv:2302.12173, 2023

[22] E. Debenedetti, J. Zhang, M. Balunović, L. Beurer-Kellner, M. Fischer, F. Tramèr, *AgentDojo: A Dynamic Environment to Evaluate Prompt Injection Attacks and Defenses for LLM Agents* In arXiv preprint arXiv:2406.13352, 2024

# 参考文献


M. Abadi, A. Chu, I. Goodfellow, H. B. McMahan, I. Mironov, K. Talwar, L. Zhang, *Deep Learning with Differential Privacy* In Proceedings of the 2016 ACM SIGSAC Conference on Computer and Communications Security, 2016, pp. 308–318.

J. Adebayo, J. Gilmer, M. Muelly, I. Goodfellow, M. Hardt, B. Kim, *Sanity Checks for Saliency Maps* In arXiv preprint arXiv:1810.03292, 2018.

A. Agarwal, A. Beygelzimer, M. Dudík, J. Langford, H. Wallach, *A Reductions Approach to Fair Classification* In Proceedings of the 35th International Conference on Machine Learning, 2018, pp. 60–69.

C. C. Aggarwal, *Recommender Systems*, Springer, 2016.

M. Alshiekh, R. Bloem, R. Ehlers, B. Könighofer, S. Niekum, U. Topcu, *Safe Reinforcement Learning via Shielding* In Proceedings of the AAAI Conference on Artificial Intelligence, 2018.

A. Angelopoulos, S. Bates, A. Fisch, L. Lei, T. Schuster, *Conformal Risk Control* In International Conference on Learning Representations, 2024.

A. N. Angelopoulos, S. Bates, *A Gentle Introduction to Conformal Prediction and Distribution-Free Uncertainty Quantification* In arXiv preprint arXiv:2107.07511, 2022.

D. W. Apley, J. Zhu, *Visualizing the Effects of Predictor Variables in Black Box Supervised Learning Models* In Journal of the Royal Statistical Society Series B: Statistical Methodology, 2020, vol. 82, no. 4, pp. 1059–1086.

M. Arjovsky, L. Bottou, I. Gulrajani, D. Lopez-Paz, *Invariant Risk Minimization* In arXiv preprint arXiv:1907.02893, 2019.

S. Arora, N. Cohen, W. Hu, Y. Luo, *Implicit Regularization in Deep Matrix Factorization* In Advances in Neural Information Processing Systems, 2019.

S. Arora, S. S. Du, W. Hu, Z. Li, R. Wang, *Fine-Grained Analysis of Optimization and Generalization for Overparameterized Two-Layer Neural Networks* In Proceedings of the 36th International Conference on Machine Learning, 2019, pp. 322–332.

A. Athalye, N. Carlini, D. Wagner, *Obfuscated Gradients Give a False Sense of Security: Circumventing Defenses to Adversarial Examples* In Proceedings of the 35th International Conference on Machine Learning, 2018, pp. 274–283.

I. Attias, S. Hanneke, A. Ramaswami, *Sample Compression Scheme Reductions* In Proceedings of the 36th International Conference on Algorithmic Learning Theory, 2025, pp. 134–162.

Y. Bai, S. Kadavath, S. Kundu, A. Askell, J. Kernion, A. Jones, A. Chen, A. Goldie, A. Mirhoseini, C. McKinnon, C. Chen, C. Olsson, C. Olah, D. Hernandez, D. Drain, D. Ganguli, D. Li, E. Tran-Johnson, E. Perez, J. Kerr, J. Mueller, J. Ladish, J. Landau, K. Ndousse, K. Lukosuite, L. Lovitt, M. Sellitto, N. Elhage, N. Schiefer, N. Mercado, N. DasSarma, R. Lasenby, R. Larson, S. Ringer, S. Johnston, S. Kravec, S. El Showk, S. Fort, T. Lanham, T. Telleen-Lawton, T. Conerly, T. Henighan, T. Hume, S. R. Bowman, Z. Hatfield-Dodds, B. Mann, D. Amodei, N. Joseph, S. McCandlish, T. Brown, J. Kaplan, *Constitutional AI: Harmlessness from AI Feedback* In arXiv preprint arXiv:2212.08073, 2022.

R. F. Barber, E. J. Candès, A. Ramdas, R. J. Tibshirani, *The Limits of Distribution-Free Conditional Predictive Inference* In arXiv preprint arXiv:1903.04684, 2020.

P. L. Bartlett, *For Valid Generalization the Size of the Weights is More Important than the Size of the Network* In Advances in Neural Information Processing Systems, 1996.

P. L. Bartlett, D. J. Foster, M. J. Telgarsky, *Spectrally-Normalized Margin Bounds for Neural Networks* In Advances in Neural Information Processing Systems 30, 2017.

P. L. Bartlett, N. Harvey, C. Liaw, A. Mehrabian, *Nearly-tight VC-dimension and Pseudodimension Bounds for Piecewise Linear Neural Networks* In Journal of Machine Learning Research, 2019, vol. 20, no. 63, pp. 1–17.

P. L. Bartlett, P. M. Long, G. Lugosi, A. Tsigler, *Benign Overfitting in Linear Regression* In Proceedings of the National Academy of Sciences, 2020, vol. 117, no. 48, pp. 30063–30070.

P. L. Bartlett, S. Mendelson, *Rademacher and Gaussian Complexities: Risk Bounds and Structural Results* In Journal of Machine Learning Research, 2002, vol. 3, pp. 463–482.

E. B. Baum, D. Haussler, *What Size Net Gives Valid Generalization?* In Advances in Neural Information Processing Systems, 1988.

M. Belkin, D. Hsu, S. Ma, S. Mandal, *Reconciling Modern Machine-Learning Practice and the Classical Bias–Variance Trade-Off* In Proceedings of the National Academy of Sciences, 2019, vol. 116, no. 32, pp. 15849–15854.

S. Ben-David, J. Blitzer, K. Crammer, A. Kulesza, F. Pereira, J. W. Vaughan, *A Theory of Learning from Different Domains* In Machine Learning, 2010, vol. 79, pp. 151–175.

S. Ben-David, T. Lu, T. Luu, D. Pál, *Impossibility Theorems for Domain Adaptation* In Proceedings of the Thirteenth International Conference on Artificial Intelligence and Statistics, 2010, pp. 129–136.

J. C. Bezdek, R. Ehrlich, W. Full, *FCM: The Fuzzy c-Means Clustering Algorithm* In Computers & Geosciences, 1984, vol. 10, no. 2-3, pp. 191–203.

A. Bifet, R. Gavaldà, *Learning from Time-Changing Data with Adaptive Windowing* In Proceedings of the 2007 SIAM International Conference on Data Mining, 2007, pp. 443–448.

C. M. Bishop, *Pattern Recognition and Machine Learning*, Springer, 2006, 1st ed.

C. M. Bishop, H. Bishop, *Deep Learning: Foundations and Concepts*, Springer, 2024.

D. M. Blei, A. Y. Ng, M. I. Jordan, *Latent Dirichlet Allocation* In Journal of Machine Learning Research, 2003, vol. 3, pp. 993–1022.

K. Bonawitz, V. Ivanov, B. Kreuter, A. Marcedone, H. B. McMahan, S. Patel, D. Ramage, A. Segal, K. Seth, *Practical Secure Aggregation for Privacy-Preserving Machine Learning* In Proceedings of the 2017 ACM SIGSAC Conference on Computer and Communications Security, 2017.

B. Bordelon, A. Atanasov, C. Pehlevan, *How Feature Learning Can Improve Neural Scaling Laws* In International Conference on Learning Representations, 2025.

L. Bourtoule, V. Chandrasekaran, C. A. Choquette-Choo, H. Jia, A. Travers, B. Zhang, D. Lie, N. Papernot, *Machine Unlearning* In 2021 IEEE Symposium on Security and Privacy, 2021.

O. Bousquet, A. Elisseeff, *Stability and Generalization* In Journal of Machine Learning Research, 2002, vol. 2, pp. 499–526.

O. Bousquet, Y. Klochkov, N. Zhivotovskiy, *Sharper Bounds for Uniformly Stable Algorithms* In Proceedings of the Thirty Third Conference on Learning Theory, 2020, pp. 610–626.

L. Breiman, *Random Forests* In Machine Learning, 2001, vol. 45, no. 1, pp. 5–32.

T. Bricken, A. Templeton, J. Batson, B. Chen, A. Jermyn, T. Conerly, N. Turner, C. Anil, C. Denison, A. Askell, R. Lasenby, Y. Wu, S. Kravec,

N. Schiefer, T. Maxwell, N. Joseph, Z. Hatfield-Dodds, A. Tamkin, K. Nguyen, B. McLean, J. E. Burke, T. Hume, S. Carter, T. Henighan, C. Olah, *Towards Monosemanticity: Decomposing Language Models With Dictionary Learning* In Transformer Circuits Thread, 2023.

G. W. Brier, *Verification of Forecasts Expressed in Terms of Probability* In Monthly Weather Review, 1950, vol. 78, no. 1, pp. 1–3.

T. B. Brown, B. Mann, N. Ryder, M. Subbiah, J. Kaplan, P. Dhariwal, A. Neelakantan, P. Shyam, G. Sastry, A. Askell, S. Agarwal, A. Herbert-Voss, G. Krueger, T. Henighan, R. Child, A. Ramesh, D. M. Ziegler, J. Wu, C. Winter, C. Hesse, M. Chen, E. Sigler, M. Litwin, S. Gray, B. Chess, J. Clark, C. Berner, S. McCandlish, A. Radford, I. Sutskever, D. Amodei, *Language Models Are Few-Shot Learners* In Advances in Neural Information Processing Systems 33, 2020, pp. 1877–1901.

N. Brukhim, D. Carmon, I. Dinur, S. Moran, A. Yehudayoff, *A Characterization of Multiclass Learnability* In Proceedings of the 63rd Annual Symposium on Foundations of Computer Science, 2022, pp. 943–955.

Y. Bu, S. Zou, V. V. Veeravalli, *Tightening Mutual Information-Based Bounds on Generalization Error* In IEEE Journal on Selected Areas in Information Theory, 2020, vol. 1, no. 1, pp. 121–130.

J. Buolamwini, T. Gebru, *Gender Shades: Intersectional Accuracy Disparities in Commercial Gender Classification* In Proceedings of the 1st Conference on Fairness, Accountability and Transparency, 2018, pp. 77–91.

C. Burns, P. Izmailov, J. H. Kirchner, B. Baker, L. Gao, L. Aschenbrenner, Y. Chen, A. Ecoffet, M. Joglekar, J. Leike, I. Sutskever, J. Wu, *Weak-to-Strong Generalization: Eliciting Strong Capabilities With Weak Supervision* In arXiv preprint arXiv:2312.09390, 2023.

Y. Cao, J. Yang, *Towards Making Systems Forget with Machine Unlearning* In 2015 IEEE Symposium on Security and Privacy, 2015.

N. Carlini, S. Chien, M. Nasr, S. Song, A. Terzis, F. Tramer, *Membership Inference Attacks From First Principles* In arXiv preprint arXiv:2112.03570, 2022.

N. Carlini, F. Tramer, E. Wallace, M. Jagielski, A. Herbert-Voss, K. Lee, A. Roberts, T. Brown, D. Song, U. Erlingsson, A. Oprea, C. Raffel, *Extracting Training Data from Large Language Models* In 30th USENIX Security Symposium, 2021.

N. Carlini, D. Wagner, *Towards Evaluating the Robustness of Neural Networks* In arXiv preprint arXiv:1608.04644, 2017.

R. Caruana, *Multitask Learning* In Machine Learning, 1997, vol. 28, pp. 41–75.

C. Chen, O. Li, C. Tao, A. J. Barnett, J. Su, C. Rudin, *This Looks Like That: Deep Learning for Interpretable Image Recognition* In Advances in Neural Information Processing Systems, 2019.

T. Chen, S. Kornblith, M. Norouzi, G. Hinton, *A Simple Framework for Contrastive Learning of Visual Representations* In Proceedings of the 37th International Conference on Machine Learning, 2020, pp. 1597–1607.

P. F. Christiano, J. Leike, T. B. Brown, M. Martic, S. Legg, D. Amodei, *Deep Reinforcement Learning from Human Preferences* In Advances in Neural Information Processing Systems 30, 2017, pp. 4299–4307.

J. Cohen, E. Rosenfeld, Z. Kolter, *Certified Adversarial Robustness via Randomized Smoothing* In Proceedings of the 36th International Conference on Machine Learning, 2019, pp. 1310–1320.

R. Colomboni, E. Esposito, A. Paudice, *An Improved Uniform Convergence Bound with Fat-Shattering Dimension* In arXiv preprint arXiv:2307.06644, 2023.

C. Cortes, V. Vapnik, *Support-Vector Networks* In Machine Learning, 1995, vol. 20, no. 3, pp. 273–297.

F. Croce, M. Hein, *Reliable Evaluation of Adversarial Robustness with an Ensemble of Diverse Parameter-Free Attacks* In Proceedings of the 37th International Conference on Machine Learning, 2020, pp. 2206–2216.

A. D'Amour, K. Heller, D. Moldovan, B. Adlam, B. Alipanahi, A. Beutel, C. Chen, J. Deaton, J. Eisenstein, M. D. Hoffman, F. Hormozdiari, N. Houlsby, S. Hou, G. Jerfel, A. Karthikesalingam, M. Lucic, Y. Ma, C. McLean, D. Mincu, A. Mitani, A. Montanari, Z. Nado, V. Natarajan, C. Nielson, T. F. Osborne, R. Raman, K. Ramasamy, R. Sayres, J. Schrouff, M. Seneviratne, S. Sequeira, H. Suresh, V. Veitch, M. Vladymyrov, X. Wang, K. Webster, S. Yadlowsky, T. Yun, X. Zhai, D. Sculley, *Underspecification Presents Challenges for Credibility in Modern Machine Learning* In arXiv preprint arXiv:2011.03395, 2020.

A. Daniely, S. Sabato, S. Ben-David, S. Shalev-Shwartz, *Multiclass Learnability and the ERM Principle* In Journal of Machine Learning Research, 2015, vol. 16, no. 72, pp. 2377–2404.

J. De Houwer, D. Barnes-Holmes, A. Moors, *What Is Learning? On the Nature and Merits of a Functional Definition of Learning* In Psychonomic Bulletin & Review, 2013, vol. 20, no. 4, pp. 631–642.

E. Debenedetti, J. Zhang, M. Balunović, L. Beurer-Kellner, M. Fischer, F. Tramèr, *AgentDojo: A Dynamic Environment to Evaluate Prompt Injection Attacks and Defenses for LLM Agents* In arXiv preprint arXiv:2406.13352, 2024.

M. P. Deisenroth, A. A. Faisal, C. S. Ong, *Mathematics for Machine Learning*, Cambridge University Press, 2020.

V. Delle Rose, A. Kozachinskiy, C. Rojas, T. Steifer, *Find a Witness or Shatter: The Landscape of Computable PAC Learning* In Proceedings of the 36th Conference on Learning Theory, 2023, pp. 511–524.

J. Devlin, M.-W. Chang, K. Lee, K. Toutanova, *BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding* In Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, 2019, pp. 4171–4186.

I. S. Dhillon, Y. Guan, B. Kulis, *Kernel k-Means, Spectral Clustering and Normalized Cuts* In Proceedings of the Tenth ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 2004, pp. 551–556.

L. Dinh, R. Pascanu, S. Bengio, Y. Bengio, *Sharp Minima Can Generalize for Deep Nets* In Proceedings of the 34th International Conference on Machine Learning, 2017, pp. 1019–1028.

F. Doshi-Velez, B. Kim, *Towards A Rigorous Science of Interpretable Machine Learning* In arXiv preprint arXiv:1702.08608, 2017.

C. Dwork, M. Hardt, T. Pitassi, O. Reingold, R. Zemel, *Fairness Through Awareness* In Proceedings of the 3rd Innovations in Theoretical Computer Science Conference, 2012.

C. Dwork, A. Roth, *The Algorithmic Foundations of Differential Privacy* In Foundations and Trends in Theoretical Computer Science, 2014, vol. 9, no. 3–4, pp. 211–407.

M. Ester, H.-P. Kriegel, J. Sander, X. Xu, *A Density-Based Algorithm for Discovering Clusters in Large Spatial Databases with Noise* In Proceedings of the Second International Conference on Knowledge Discovery and Data Mining, 1996, pp. 226–231.

S. Farquhar, J. Kossen, L. Kuhn, Y. Gal, *Detecting Hallucinations in Large Language Models Using Semantic Entropy* In Nature, 2024, vol. 630, pp. 625–630.

C. Finn, P. Abbeel, S. Levine, *Model-Agnostic Meta-Learning for Fast Adaptation of Deep Networks* In Proceedings of the 34th International Conference on Machine Learning, 2017, pp. 1126–1135.

J. H. Friedman, *Greedy Function Approximation: A Gradient Boosting Machine* In The Annals of Statistics, 2001, vol. 29, no. 5, pp. 1189–1232.

Y. Gal, Z. Ghahramani, *Dropout as a Bayesian Approximation: Representing Model Uncertainty in Deep Learning* In Proceedings of the 33rd International Conference on Machine Learning, 2016, pp. 1050–1059.

Y. Gal, R. Islam, Z. Ghahramani, *Deep Bayesian Active Learning with Image Data* In Proceedings of the 34th International Conference on Machine Learning, 2017, pp. 1183–1192.

Y. Ganin, E. Ustinova, H. Ajakan, P. Germain, H. Larochelle, F. Laviolette, M. Marchand, V. Lempitsky, *Domain-Adversarial Training of Neural Networks* In Journal of Machine Learning Research, 2016, vol. 17, no. 59, pp. 1–35.

L. Gao, J. Schulman, J. Hilton, *Scaling Laws for Reward Model Overoptimization* In arXiv preprint arXiv:2210.10760, 2022.

T. Gebru, J. Morgenstern, B. Vecchione, J. W. Vaughan, H. Wallach, H. Daumé III, K. Crawford, *Datasheets for Datasets* In arXiv preprint arXiv:1803.09010, 2021.

Y. Geifman, R. El-Yaniv, *SelectiveNet: A Deep Neural Network with an Integrated Reject Option* In Proceedings of the 36th International Conference on Machine Learning, 2019, pp. 2151–2159.

R. Geirhos, J.-H. Jacobsen, C. Michaelis, R. Zemel, W. Brendel, M. Bethge, F. A. Wichmann, *Shortcut Learning in Deep Neural Networks* In Nature Machine Intelligence, 2020.

P. Germain, A. Habrard, F. Laviolette, E. Morvant, *An Improvement to the Domain Adaptation Bound in a PAC-Bayesian Context* In arXiv preprint arXiv:1501.03002, 2015.

A. Géron, *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow*, O'Reilly Media, 2022, 3rd ed.

I. Gibbs, E. Candès, *Adaptive Conformal Inference Under Distribution Shift* In arXiv preprint arXiv:2106.00170, 2021.

I. Goodfellow, Y. Bengio, A. Courville, *Deep Learning*, MIT Press, 2016.

I. J. Goodfellow, J. Shlens, C. Szegedy, *Explaining and Harnessing Adversarial Examples* In arXiv preprint arXiv:1412.6572, 2015.

Google, *Recommendation Systems Overview*, Aug. 25, 2025, URL: https://developers.google.com/machine-learning/recommendation/overview/types.

P. Gourdeau, T. Lechner, R. Urner, *On the Computability of Multiclass PAC Learning* In arXiv preprint arXiv:2502.06089, 2025.

K. Greshake, S. Abdelnabi, S. Mishra, C. Endres, T. Holz, M. Fritz, *Not What You've Signed Up For: Compromising Real-World LLM-Integrated Appli-*

*cations with Indirect Prompt Injection* In arXiv preprint arXiv:2302.12173, 2023.

T. Gu, B. Dolan-Gavitt, S. Garg, *BadNets: Identifying Vulnerabilities in the Machine Learning Model Supply Chain* In arXiv preprint arXiv:1708.06733, 2017.

M. Y. Guan, M. Wang, M. Carroll, Z. Dou, A. Y. Wei, M. Williams, B. Arnav, J. Huizinga, I. D. Kivlichan, A. Glaese, J. Pachocki, B. Baker, *Monitoring Monitorability* In Proceedings of the 43rd International Conference on Machine Learning, 2026, pp. 37538–37602.

I. Gulrajani, D. Lopez-Paz, *In Search of Lost Domain Generalization* In International Conference on Learning Representations, 2021.

S. Gunasekar, B. E. Woodworth, S. Bhojanapalli, B. Neyshabur, N. Srebro, *Implicit Regularization in Matrix Factorization* In Advances in Neural Information Processing Systems, 2017.

C. Guo, T. Goldstein, A. Hannun, L. van der Maaten, *Certified Data Removal from Machine Learning Models* In Proceedings of the 37th International Conference on Machine Learning, 2020, pp. 3832–3842.

C. Guo, G. Pleiss, Y. Sun, K. Q. Weinberger, *On Calibration of Modern Neural Networks* In Proceedings of the 34th International Conference on Machine Learning, 2017, pp. 1321–1330.

S. Hanneke, *The Optimal Sample Complexity of PAC Learning* In Journal of Machine Learning Research, 2016, vol. 17, no. 38, pp. 1–15.

A. Hard, K. Rao, R. Mathews, S. Ramaswamy, F. Beaufays, S. Augenstein, H. Eichner, C. Kiddon, D. Ramage, *Federated Learning for Mobile Keyboard Prediction* In arXiv preprint arXiv:1811.03604, 2018.

M. Hardt, E. Price, N. Srebro, *Equality of Opportunity in Supervised Learning* In arXiv preprint arXiv:1610.02413, 2016.

M. Hardt, B. Recht, Y. Singer, *Train Faster, Generalize Better: Stability of Stochastic Gradient Descent* In Proceedings of the 33rd International Conference on Machine Learning, 2016, pp. 1225–1234.

T. Hastie, R. Tibshirani, *Generalized Additive Models* In Statistical Science, 1986, vol. 1, no. 3, pp. 297–310.

T. Hastie, R. Tibshirani, J. Friedman, *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*, Springer, 2009, 2nd ed.

Ú. Hébert-Johnson, M. Kim, O. Reingold, G. Rothblum, *Multicalibration: Calibration for the (Computationally-Identifiable) Masses* In Proceedings of the 35th International Conference on Machine Learning, 2018, pp. 1939–1948.

D. Hendrycks, T. Dietterich, *Benchmarking Neural Network Robustness to Common Corruptions and Perturbations* In International Conference on Learning Representations, 2019.

D. Hendrycks, K. Gimpel, *A Baseline for Detecting Misclassified and Out-of-Distribution Examples in Neural Networks* In International Conference on Learning Representations, 2017.

D. Hendrycks, M. Mazeika, T. Dietterich, *Deep Anomaly Detection with Outlier Exposure* In International Conference on Learning Representations, 2019.

D. Hendrycks, N. Mu, E. D. Cubuk, B. Zoph, J. Gilmer, B. Lakshminarayanan, *AugMix: A Simple Data Processing Method to Improve Robustness and Uncertainty* In International Conference on Learning Representations, 2020.

J. Hoffmann, S. Borgeaud, A. Mensch, et al., *Training Compute-Optimal Large Language Models* In arXiv preprint arXiv:2203.15556, 2022.

T. M. Hospedales, A. Antoniou, P. Micaelli, A. J. Storkey, *Meta-Learning in Neural Networks: A Survey* In IEEE Transactions on Pattern Analysis and Machine Intelligence, 2022, vol. 44, no. 9, pp. 5149–5169.

X. Huang, A. Yang, S. Bhattamishra, Y. Sarrof, A. Krebs, H. Zhou, P. Nakkiran, M. Hahn, *A Formal Framework for Understanding Length Generalization in Transformers* In International Conference on Learning Representations, 2025.

E. Hubinger, C. Denison, J. Mu, M. Lambert, M. Tong, M. MacDiarmid, T. Lanham, D. M. Ziegler, T. Maxwell, N. Cheng, A. Jermyn, A. Askell, A. Radhakrishnan, C. Anil, D. Duvenaud, D. Ganguli, F. Barez, J. Clark, K. Ndousse, K. Sachan, M. Sellitto, M. Sharma, N. DasSarma, R. Grosse, S. Kravec, Y. Bai, Z. Witten, M. Favaro, J. Brauner, H. Karnofsky, P. Christiano, S. R. Bowman, L. Graham, J. Kaplan, S. Mindermann, R. Greenblatt, B. Shlegeris, N. Schiefer, E. Perez, *Sleeper Agents: Training Deceptive LLMs that Persist Through Safety Training* In arXiv preprint arXiv:2401.05566, 2024.

D. Hume, *An Enquiry Concerning Human Understanding*, 1748.

C. Huyen, *Designing Machine Learning Systems*, O'Reilly Media, 2022.

A. Jacot, F. Gabriel, C. Hongler, *Neural Tangent Kernel: Convergence and Generalization in Neural Networks* In Advances in Neural Information Processing Systems, 2018.

G. James, D. Witten, T. Hastie, R. Tibshirani, *An Introduction to Statistical Learning*, Springer, 2021, 2nd ed.

T. Joachims, *Transductive Inference for Text Classification using Support Vector Machines* In Proceedings of the 16th International Conference on Machine Learning, 1999, pp. 200–209.

T. Joachims, A. Swaminathan, T. Schnabel, *Unbiased Learning-to-Rank with Biased Feedback*, 2016, arXiv: 1608.04468, URL: https://arxiv.org/abs/1608.04468.

D. Jurafsky, J. H. Martin, *Speech and Language Processing*, Prentice Hall, 2009, 2nd ed.

J. Kaplan, S. McCandlish, T. Henighan, T. B. Brown, B. Chess, R. Child, S. Gray, A. Radford, J. Wu, D. Amodei, *Scaling Laws for Neural Language Models* In arXiv preprint arXiv:2001.08361, 2020.

A.-H. Karimi, B. Schölkopf, I. Valera, *Algorithmic Recourse: from Counterfactual Explanations to Interventions* In Proceedings of the 2021 ACM Conference on Fairness, Accountability, and Transparency, 2021.

H. Karimi, J. Nutini, M. Schmidt, *Linear Convergence of Gradient and Proximal-Gradient Methods Under the Polyak–Lojasiewicz Condition* In arXiv preprint arXiv:1608.04636, 2016.

G. Katz, C. Barrett, D. L. Dill, K. Julian, M. J. Kochenderfer, *Reluplex: An Efficient SMT Solver for Verifying Deep Neural Networks* In arXiv preprint arXiv:1702.01135, 2017.

M. Kearns, S. Neel, A. Roth, Z. S. Wu, *Preventing Fairness Gerrymandering: Auditing and Learning for Subgroup Fairness* In Proceedings of the 35th International Conference on Machine Learning, 2018, pp. 2564–2572.

A. Kendall, Y. Gal, R. Cipolla, *Multi-Task Learning Using Uncertainty to Weigh Losses for Scene Geometry and Semantics* In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2018, pp. 7482–7491.

P. Khosla, P. Teterwak, C. Wang, A. Sarna, Y. Tian, P. Isola, A. Maschinot, C. Liu, D. Krishnan, *Supervised Contrastive Learning* In Advances in Neural Information Processing Systems 33, 2020, pp. 18661–18673.

B. Kim, M. Wattenberg, J. Gilmer, C. Cai, J. Wexler, F. Viegas, R. Sayres, *Interpretability Beyond Feature Attribution: Quantitative Testing with Concept Activation Vectors (TCAV)* In Proceedings of the 35th International Conference on Machine Learning, 2018, pp. 2668–2677.

J. Kirkpatrick, R. Pascanu, N. Rabinowitz, J. Veness, G. Desjardins, A. A. Rusu, K. Milan, J. Quan, T. Ramalho, A. Grabska-Barwinska, D. Hassabis, C. Clopath, D. Kumaran, R. Hadsell, *Overcoming Catastrophic Forgetting in Neural Networks* In Proceedings of the National Academy of Sciences, 2017.

J. Kleinberg, S. Mullainathan, M. Raghavan, *Inherent Trade-Offs in the Fair Determination of Risk Scores* In arXiv preprint arXiv:1609.05807, 2016.

M. Kleppmann, C. Riccomini, *Designing Data-Intensive Applications*, O'Reilly Media, 2026, 2nd ed.

P. W. Koh, P. Liang, *Understanding Black-box Predictions via Influence Functions* In Proceedings of the 34th International Conference on Machine Learning, 2017, pp. 1885–1894.

P. W. Koh, T. Nguyen, Y. S. Tang, S. Mussmann, E. Pierson, B. Kim, P. Liang, *Concept Bottleneck Models* In Proceedings of the 37th International Conference on Machine Learning, 2020, pp. 5338–5348.

P. W. Koh, S. Sagawa, H. Marklund, S. M. Xie, M. Zhang, A. Balsubramani, W. Hu, M. Yasunaga, R. L. Phillips, I. Gao, T. Lee, E. David, I. Stavness, W. Guo, B. Earnshaw, I. Haque, S. M. Beery, J. Leskovec, A. Kundaje, E. Pierson, S. Levine, C. Finn, P. Liang, *WILDS: A Benchmark of in-the-Wild Distribution Shifts* In Proceedings of the 38th International Conference on Machine Learning, 2021, pp. 5637–5664.

D. Koller, N. Friedman, *Probabilistic Graphical Models: Principles and Techniques*, MIT Press, 2009.

L. Kuhn, Y. Gal, S. Farquhar, *Semantic Uncertainty: Linguistic Invariances for Uncertainty Estimation in Natural Language Generation* In International Conference on Learning Representations, 2023.

M. J. Kusner, J. R. Loftus, C. Russell, R. Silva, *Counterfactual Fairness* In Advances in Neural Information Processing Systems, 2017.

H. Lakkaraju, J. Kleinberg, J. Leskovec, J. Ludwig, S. Mullainathan, *The Selective Labels Problem: Evaluating Algorithmic Predictions in the Presence of Unobservables* In Proceedings of the 23rd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 2017, pp. 275–284.

B. Lakshminarayanan, A. Pritzel, C. Blundell, *Simple and Scalable Predictive Uncertainty Estimation using Deep Ensembles* In Advances in Neural Information Processing Systems, 2017.

Y. LeCun, Y. Bengio, G. Hinton, *Deep Learning* In Nature, 2015, vol. 521, pp. 436–444.

Y. LeCun, L. Bottou, Y. Bengio, P. Haffner, *Gradient-Based Learning Applied to Document Recognition* In Proceedings of the IEEE, 1998, vol. 86, no. 11, pp. 2278–2324.

G. J. Lee, J. Pradeepkumar, J. Sun, *Test-Time Adaptation for EEG Foundation Models: A Systematic Study under Real-World Distribution Shifts* In

Proceedings of the 11th Machine Learning for Healthcare Conference, 2026, pp. 948–984.

Y. Lei, Y. Ying, *Fine-Grained Analysis of Stability and Generalization for Stochastic Gradient Descent* In Proceedings of the 37th International Conference on Machine Learning, 2020, pp. 5809–5819.

S. Levine, A. Kumar, G. Tucker, J. Fu, *Offline Reinforcement Learning: Tutorial, Review, and Perspectives on Open Problems* In arXiv preprint arXiv:2005.01643, 2020.

H. Li, R. Wen, S. Shi, N. Zhang, Y. Vorobeychik, C. Xiao, *AgentDyn: Are Your Agent Security Defenses Deployable in Real-World Dynamic Environments?* In arXiv preprint arXiv:2602.03117, 2026.

K. Li, O. Patel, F. Viégas, H. Pfister, M. Wattenberg, *Inference-Time Intervention: Eliciting Truthful Answers from a Language Model* In arXiv preprint arXiv:2306.03341, 2023.

L. Li, W. Chu, J. Langford, R. E. Schapire, *A Contextual-Bandit Approach to Personalized News Article Recommendation* In Proceedings of the 19th International Conference on World Wide Web, 2010.

Y. Li, M. E. Ildiz, D. Papailiopoulos, S. Oymak, *Transformers as Algorithms: Generalization and Stability in In-context Learning* In arXiv preprint arXiv:2301.07067, 2023.

H. Lightman, V. Kosaraju, Y. Burda, H. Edwards, B. Baker, T. Lee, J. Leike, J. Schulman, I. Sutskever, K. Cobbe, *Let's Verify Step by Step* In arXiv preprint arXiv:2305.20050, 2023.

K. Liu, B. Dolan-Gavitt, S. Garg, *Fine-Pruning: Defending Against Backdooring Attacks on Deep Neural Networks* In arXiv preprint arXiv:1805.12185, 2018.

L. T. Liu, S. Dean, E. Rolf, M. Simchowitz, M. Hardt, *Delayed Impact of Fair Machine Learning* In Proceedings of the 35th International Conference on Machine Learning, 2018, pp. 3150–3158.

W. Liu, X. Wang, J. D. Owens, Y. Li, *Energy-based Out-of-distribution Detection* In arXiv preprint arXiv:2010.03759, 2020.

G. Loaiza-Ganem, K. Zhang, W. Cui, M. T. Law, K. K. Leung, *Conf-Gen: Conformal Uncertainty Quantification for Generative Models* In Proceedings of the 43rd International Conference on Machine Learning, 2026, pp. 80383–80412.

S. Lotfi, M. A. Finzi, Y. Kuang, T. G. J. Rudner, M. Goldblum, A. G. Wilson, *Non-Vacuous Generalization Bounds for Large Language Models* In Proceedings of the 41st International Conference on Machine Learning, 2024, pp. 32801–32818.

S. Lotfi, Y. Kuang, B. Amos, M. Goldblum, M. Finzi, A. G. Wilson, *Unlocking Tokens as Data Points for Generalization Bounds on Larger Language Models* In Advances in Neural Information Processing Systems, 2024.

Y. Lou, R. Caruana, J. Gehrke, G. Hooker, *Accurate Intelligible Models with Pairwise Interactions* In Proceedings of the 19th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 2013.

S. Lundberg, S.-I. Lee, *A Unified Approach to Interpreting Model Predictions* In arXiv preprint arXiv:1705.07874, 2017.

A. Madry, A. Makelov, L. Schmidt, D. Tsipras, A. Vladu, *Towards Deep Learning Models Resistant to Adversarial Attacks* In International Conference on Learning Representations, 2018.

C. D. Manning, P. Raghavan, H. Schütze, *Introduction to Information Retrieval*, Cambridge University Press, 2008.

Y. Mansour, M. Mohri, A. Rostamizadeh, *Domain Adaptation: Learning Bounds and Algorithms* In Proceedings of the 22nd Annual Conference on Learning Theory, 2009.

A. Maurer, *A Note on the PAC Bayesian Theorem*, 2004, arXiv: cs/0411099.

A. Maurer, M. Pontil, B. Romera-Paredes, *The Benefit of Multitask Representation Learning* In Journal of Machine Learning Research, 2016, vol. 17, no. 81, pp. 1–32.

P. Mayilvahanan, R. S. Zimmermann, T. Wiedemer, E. Rusak, A. Juhos, M. Bethge, W. Brendel, *In Search of Forgotten Domain Generalization* In Proceedings on "I Can't Believe It's Not Better: Challenges in Applied Deep Learning" at ICLR 2025 Workshops, 2025, pp. 90–130.

W. S. McCulloch, W. Pitts, *A Logical Calculus of the Ideas Immanent in Nervous Activity* In The Bulletin of Mathematical Biophysics, 1943, vol. 5, pp. 115–133.

H. B. McMahan, G. Holt, D. Sculley, M. Young, D. Ebner, J. Grady, L. Nie, T. Phillips, E. Davydov, D. Golovin, S. Chikkerur, D. Liu, M. Wattenberg, A. M. Hrafnkelsson, T. Boulos, J. Kubica, *Ad Click Prediction: A View from the Trenches* In Proceedings of the 19th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 2013, pp. 1222–1230.

H. B. McMahan, E. Moore, D. Ramage, S. Hampson, B. Agüera y Arcas, *Communication-Efficient Learning of Deep Networks from Decentralized Data* In Proceedings of the 20th International Conference on Artificial Intelligence and Statistics, 2017, pp. 1273–1282.

S. Mei, T. Misiakiewicz, A. Montanari, *Mean-field Theory of Two-layers Neural Networks: Dimension-free Bounds and Kernel Limit* In arXiv preprint arXiv:1902.06015, 2019.

S. Mei, A. Montanari, P.-M. Nguyen, *A Mean Field View of the Landscape of Two-Layers Neural Networks* In arXiv preprint arXiv:1804.06561, 2018.

K. Meng, D. Bau, A. Andonian, Y. Belinkov, *Locating and Editing Factual Associations in GPT* In Advances in Neural Information Processing Systems, 2022.

I. Mironov, *Rényi Differential Privacy* In 2017 IEEE 30th Computer Security Foundations Symposium, 2017.

M. Mitchell, S. Wu, A. Zaldivar, P. Barnes, L. Vasserman, B. Hutchinson, E. Spitzer, I. D. Raji, T. Gebru, *Model Cards for Model Reporting* In Proceedings of the Conference on Fairness, Accountability, and Transparency, 2019.

T. M. Mitchell, *Machine Learning*, McGraw-Hill, 1997, 1st ed.

V. Mnih, K. Kavukcuoglu, D. Silver, A. A. Rusu, J. Veness, M. G. Bellemare, A. Graves, M. Riedmiller, A. K. Fidjeland, G. Ostrovski, S. Petersen, C. Beattie, A. Sadik, I. Antonoglou, H. King, D. Kumaran, D. Wierstra, S. Legg, D. Hassabis, *Human-Level Control through Deep Reinforcement Learning* In Nature, 2015, vol. 518, pp. 529–533.

M. Mohri, A. Rostamizadeh, A. Talwalkar, *Foundations of Machine Learning*, The MIT Press, 2018, 2nd ed.

S. Moran, A. Yehudayoff, *Sample Compression Schemes for VC Classes* In Journal of the ACM, 2016, vol. 63, no. 3, pp. 21:1–21:10.

K. Muandet, D. Balduzzi, B. Schölkopf, *Domain Generalization via Invariant Feature Representation* In Proceedings of the 30th International Conference on Machine Learning, 2013, pp. 10–18.

K. P. Murphy, *Machine Learning: A Probabilistic Perspective*, MIT Press, 2012.

K. P. Murphy, *Probabilistic Machine Learning*, The MIT Press, 2023.

K. P. Murphy, *Probabilistic Machine Learning: An Introduction*, MIT Press, 2022.

National Institute of Standards and Technology, *Artificial Intelligence Risk Management Framework (AI RMF 1.0)*, tech. rep. NIST AI 100-1, National Institute of Standards and Technology, 2023.

A. Y. Ng, M. I. Jordan, *On Discriminative vs. Generative Classifiers: A Comparison of Logistic Regression and Naive Bayes* In Advances in Neural Information Processing Systems 14, 2001, pp. 841–848.

A. Y. Ng, S. Russell, *Algorithms for Inverse Reinforcement Learning* In Proceedings of the 17th International Conference on Machine Learning, 2000.

L. Oakden-Rayner, J. Dunnmon, G. Carneiro, C. Ré, *Hidden Stratification Causes Clinically Meaningful Failures in Machine Learning for Medical Imaging* In arXiv preprint arXiv:1909.12475, 2019.

L. Ouyang, J. Wu, X. Jiang, D. Almeida, C. L. Wainwright, P. Mishkin, C. Zhang, S. Agarwal, K. Slama, A. Ray, J. Schulman, J. Hilton, F. Kelton, L. Miller, M. Simens, A. Askell, P. Welinder, P. Christiano, J. Leike, R. Lowe, *Training Language Models to Follow Instructions with Human Feedback* In arXiv preprint arXiv:2203.02155, 2022.

Y. Ovadia, E. Fertig, J. Ren, Z. Nado, D. Sculley, S. Nowozin, J. V. Dillon, B. Lakshminarayanan, J. Snoek, *Can You Trust Your Model's Uncertainty? Evaluating Predictive Uncertainty Under Dataset Shift* In Advances in Neural Information Processing Systems, 2019.

N. Papernot, M. Abadi, Ú. Erlingsson, I. Goodfellow, K. Talwar, *Semi-supervised Knowledge Transfer for Deep Learning from Private Training Data* In International Conference on Learning Representations, 2017.

N. Papernot, S. Song, I. Mironov, A. Raghunathan, K. Talwar, Ú. Erlingsson, *Scalable Private Learning with PATE* In International Conference on Learning Representations, 2018.

A. Parrish, A. Chen, N. Nangia, V. Padmakumar, J. Phang, J. Thompson, P. M. Htut, S. R. Bowman, *BBQ: A Hand-Built Bias Benchmark for Question Answering* In Findings of the Association for Computational Linguistics: ACL 2022, 2022, pp. 2086–2105.

A. Power, Y. Burda, H. Edwards, I. Babuschkin, V. Misra, *Grokking: Generalization Beyond Overfitting on Small Algorithmic Datasets* In arXiv preprint arXiv:2201.02177, 2022.

G. Pruthi, F. Liu, S. Kale, M. Sundararajan, *Estimating Training Data Influence by Tracing Gradient Descent* In Advances in Neural Information Processing Systems, 2020.

A. Radford, J. W. Kim, C. Hallacy, A. Ramesh, G. Goh, S. Agarwal, G. Sastry, A. Askell, P. Mishkin, J. Clark, G. Krueger, I. Sutskever, *Learning Transferable Visual Models from Natural Language Supervision* In Proceedings of the 38th International Conference on Machine Learning, 2021, pp. 8748–8763.

R. Rafailov, A. Sharma, E. Mitchell, S. Ermon, C. D. Manning, C. Finn, *Direct Preference Optimization: Your Language Model is Secretly a Reward Model* In arXiv preprint arXiv:2305.18290, 2023.

C. E. Rasmussen, C. K. I. Williams, *Gaussian Processes for Machine Learning*, MIT Press, 2006.

A. Ratner, S. H. Bach, H. Ehrenberg, J. Fries, S. Wu, C. Ré, *Snorkel: Rapid Training Data Creation with Weak Supervision* In Proceedings of the VLDB Endowment, 2017, vol. 11, no. 3, pp. 269–282.

N. Razin, N. Cohen, *Implicit Regularization in Deep Learning May Not Be Explainable by Norms* In Advances in Neural Information Processing Systems, 2020.

S.-A. Rebuffi, A. Kolesnikov, G. Sperl, C. H. Lampert, *iCaRL: Incremental Classifier and Representation Learning* In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2017, pp. 5533–5542.

M. T. Ribeiro, S. Singh, C. Guestrin, *"Why Should I Trust You?": Explaining the Predictions of Any Classifier* In arXiv preprint arXiv:1602.04938, 2016.

M. T. Ribeiro, T. Wu, C. Guestrin, S. Singh, *Beyond Accuracy: Behavioral Testing of NLP Models with CheckList* In Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics, 2020, pp. 4902–4912.

Y. Romano, E. Patterson, E. J. Candès, *Conformalized Quantile Regression* In arXiv preprint arXiv:1905.03222, 2019.

Y. Romano, M. Sesia, E. Candès, *Classification with Valid and Adaptive Coverage* In Advances in Neural Information Processing Systems, 2020.

F. Rosenblatt, *The Perceptron: A Probabilistic Model for Information Storage and Organization in the Brain* In Psychological Review, 1958, vol. 65, no. 6, pp. 386–408.

E. Rosenfeld, P. Ravikumar, A. Risteski, *The Risks of Invariant Risk Minimization* In International Conference on Learning Representations, 2021.

S. Ross, G. Gordon, D. Bagnell, *A Reduction of Imitation Learning and Structured Prediction to No-Regret Online Learning* In Proceedings of the Fourteenth International Conference on Artificial Intelligence and Statistics, 2011, pp. 627–635.

D. E. Rumelhart, G. E. Hinton, R. J. Williams, *Learning representations by back-propagating errors* In Nature, 1986, vol. 323, no. 6088, pp. 533–536.

D. Russo, J. Zou, *Controlling Bias in Adaptive Data Analysis Using Information Theory* In Proceedings of the 19th International Conference on Artificial Intelligence and Statistics, 2016, pp. 1232–1240.

S. Sagawa, P. W. Koh, T. B. Hashimoto, P. Liang, *Distributionally Robust Neural Networks for Group Shifts: On the Importance of Regularization*

*for Worst-Case Generalization* In International Conference on Learning Representations, 2020.

A. L. Samuel, *Some Studies in Machine Learning Using the Game of Checkers* In IBM Journal of Research and Development, 1959, vol. 3, no. 3, pp. 210–229.

R. Schaeffer, B. Miranda, S. Koyejo, *Are Emergent Abilities of Large Language Models a Mirage?* In Advances in Neural Information Processing Systems 36, 2023.

R. R. Selvaraju, M. Cogswell, A. Das, R. Vedantam, D. Parikh, D. Batra, *Grad-CAM: Visual Explanations from Deep Networks via Gradient-based Localization* In Proceedings of the IEEE International Conference on Computer Vision, 2017.

A. Shafahi, W. R. Huang, M. Najibi, O. Suciu, C. Studer, T. Dumitras, T. Goldstein, *Poison Frogs! Targeted Clean-Label Poisoning Attacks on Neural Networks* In arXiv preprint arXiv:1804.00792, 2018.

S. Shalev-Shwartz, S. Ben-David, *Understanding Machine Learning: From Theory to Algorithms*, Cambridge University Press, 2014, 1st ed.

S. Shalev-Shwartz, O. Shamir, N. Srebro, K. Sridharan, *Learnability, Stability and Uniform Convergence* In Journal of Machine Learning Research, 2010, vol. 11, no. 90, pp. 2635–2670.

R. Shokri, M. Stronati, C. Song, V. Shmatikov, *Membership Inference Attacks against Machine Learning Models* In 2017 IEEE Symposium on Security and Privacy, 2017.

D. Silver, A. Huang, C. J. Maddison, A. Guez, L. Sifre, G. van den Driessche, J. Schrittwieser, I. Antonoglou, V. Panneershelvam, M. Lanctot, S. Dieleman, D. Grewe, J. Nham, N. Kalchbrenner, I. Sutskever, T. Lillicrap, M. Leach, K. Kavukcuoglu, T. Graepel, D. Hassabis, *Mastering the Game of Go with Deep Neural Networks and Tree Search* In Nature, 2016, vol. 529, pp. 484–489.

A. J. Smola, T.-T. Frieß, B. Schölkopf, *Semiparametric Support Vector and Linear Programming Machines* In Advances in Neural Information Processing Systems 11, 1998.

C. Snell, J. Lee, K. Xu, A. Kumar, *Scaling LLM Test-Time Compute Optimally Can be More Effective than Scaling Parameters for Reasoning* In International Conference on Learning Representations, 2025.

K. Sohn, D. Berthelot, C.-L. Li, Z. Zhang, N. Carlini, E. D. Cubuk, A. Kurakin, H. Zhang, C. Raffel, *FixMatch: Simplifying Semi-Supervised Learning with Consistency and Confidence* In Advances in Neural Information Processing Systems 33, 2020, pp. 596–608.

D. Soudry, E. Hoffer, M. S. Nacson, S. Gunasekar, N. Srebro, *The Implicit Bias of Gradient Descent on Separable Data* In Journal of Machine Learning Research, 2018, vol. 19, no. 70, pp. 1–57.

T. Steinke, L. Zakynthinou, *Reasoning About Generalization via Conditional Mutual Information* In Proceedings of the Thirty Third Conference on Learning Theory, 2020, pp. 3437–3452.

C. Strobl, A.-L. Boulesteix, A. Zeileis, T. Hothorn, *Bias in Random Forest Variable Importance Measures: Illustrations, Sources and a Solution* In BMC Bioinformatics, 2007, vol. 8, pp. 25.

M. Sundararajan, A. Taly, Q. Yan, *Axiomatic Attribution for Deep Networks* In Proceedings of the 34th International Conference on Machine Learning, 2017, pp. 3319–3328.

R. S. Sutton, A. G. Barto, *Reinforcement Learning: An Introduction*, MIT Press, 2018, 2nd ed.

C. Szegedy, W. Zaremba, I. Sutskever, J. Bruna, D. Erhan, I. Goodfellow, R. Fergus, *Intriguing Properties of Neural Networks* In arXiv preprint arXiv:1312.6199, 2014.

R. Szeliski, *Computer Vision*, Springer, 2022, 2nd ed.

C. Szepesvári, *Algorithms for Reinforcement Learning*, Morgan & Claypool Publishers, 2010.

M. E. Tipping, C. M. Bishop, *Probabilistic Principal Component Analysis* In Journal of the Royal Statistical Society: Series B (Statistical Methodology), 1999, vol. 61, no. 3, pp. 611–622.

F. Tramèr, F. Zhang, A. Juels, M. K. Reiter, T. Ristenpart, *Stealing Machine Learning Models via Prediction APIs* In arXiv preprint arXiv:1609.02943, 2016.

B. Tran, J. Li, A. Madry, *Spectral Signatures in Backdoor Attacks* In Advances in Neural Information Processing Systems, 2018.

A. M. Turing, *Computing Machinery and Intelligence* In Mind, 1950, vol. 59, no. 236, pp. 433–460.

B. Ustun, A. Spangher, Y. Liu, *Actionable Recourse in Linear Classification* In Proceedings of the Conference on Fairness, Accountability, and Transparency, 2019.

L. G. Valiant, *A Theory of the Learnable* In Communications of the ACM, 1984, vol. 27, no. 11, pp. 1134–1142.

V. N. Vapnik, A. Y. Chervonenkis, *On the Uniform Convergence of Relative Frequencies of Events to Their Probabilities* In Theory of Probability and Its Applications, 1971, vol. 16, no. 2, pp. 264–280.

G. M. van de Ven, A. S. Tolias, *Three Scenarios for Continual Learning* In arXiv preprint arXiv:1904.07734, 2019.

S. Wachter, B. Mittelstadt, C. Russell, *Counterfactual Explanations without Opening the Black Box: Automated Decisions and the GDPR* In Harvard Journal of Law & Technology, 2018.

B. Wang, X. Qiao, *Conformal Prediction Under Generalized Covariate Shift with Posterior Drift* In Proceedings of the 28th International Conference on Artificial Intelligence and Statistics, 2025, pp. 4888–4896.

B. Wang, Y. Yao, S. Shan, H. Li, B. Viswanath, H. Zheng, B. Y. Zhao, *Neural Cleanse: Identifying and Mitigating Backdoor Attacks in Neural Networks* In 2019 IEEE Symposium on Security and Privacy, 2019, pp. 707–723.

D. Wang, E. Shelhamer, S. Liu, B. Olshausen, T. Darrell, *Tent: Fully Test-Time Adaptation by Entropy Minimization* In International Conference on Learning Representations, 2021.

Y. Wang, Q. Yao, J. T. Kwok, L. M. Ni, *Generalizing from a Few Examples: A Survey on Few-Shot Learning* In ACM Computing Surveys, 2020, vol. 53, no. 3, pp. 1–34.

Y. Wang, Y. Zhou, S. Fu, Y. Chen, Y. Jing, L. Rutkowski, D. Tao, *Towards a Theoretical Understanding of In-context Learning: Stability and Non-I.I.D Generalisation* In International Conference on Learning Representations, 2026.

J. H. Ward Jr., *Hierarchical Grouping to Optimize an Objective Function* In Journal of the American Statistical Association, 1963, vol. 58, no. 301, pp. 236–244.

K. Q. Weinberger, L. K. Saul, *Distance Metric Learning for Large Margin Nearest Neighbor Classification* In Journal of Machine Learning Research, 2009, vol. 10, no. 9, pp. 207–244.

S. M. Xie, A. Raghunathan, P. Liang, T. Ma, *An Explanation of In-context Learning as Implicit Bayesian Inference* In International Conference on Learning Representations, 2022.

A. Xu, M. Raginsky, *Information-Theoretic Analysis of Generalization Capability of Learning Algorithms* In Advances in Neural Information Processing Systems, 2017.

D. Yin, Y. Chen, K. Ramchandran, P. Bartlett, *Byzantine-Robust Distributed Learning: Towards Optimal Statistical Rates* In Proceedings of the 35th International Conference on Machine Learning, 2018, pp. 5650–5659.

J. Yosinski, J. Clune, Y. Bengio, H. Lipson, *How Transferable Are Features in Deep Neural Networks?* In Advances in Neural Information Processing Systems 27, 2014, pp. 3320–3328.

R. Zemel, Y. Wu, K. Swersky, T. Pitassi, C. Dwork, *Learning Fair Representations* In Proceedings of the 30th International Conference on Machine Learning, 2013, pp. 325–333.

A. Zhang, Z. C. Lipton, M. Li, A. J. Smola, *Dive into Deep Learning*, Cambridge University Press, 2023.

B. H. Zhang, B. Lemoine, M. Mitchell, *Mitigating Unwanted Biases with Adversarial Learning* In arXiv preprint arXiv:1801.07593, 2018.

C. Zhang, S. Bengio, M. Hardt, B. Recht, O. Vinyals, *Understanding Deep Learning (Still) Requires Rethinking Generalization* In Communications of the ACM, 2021, vol. 64, no. 3, pp. 107–115.

H. Zhang, Y. Yu, J. Jiao, E. P. Xing, L. El Ghaoui, M. I. Jordan, *Theoretically Principled Trade-off between Robustness and Accuracy* In Proceedings of the 36th International Conference on Machine Learning, 2019, pp. 7472–7482.

H. Zhang, M. Cisse, Y. N. Dauphin, D. Lopez-Paz, *mixup: Beyond Empirical Risk Minimization* In International Conference on Learning Representations, 2018.

R. Zhang, L. Lin, Y. Bai, S. Mei, *Negative Preference Optimization: From Catastrophic Collapse to Effective Unlearning* In arXiv preprint arXiv:2404.05868, 2024.

Z. Zhou, M. Yang, S.-Y. Tian, K.-Y. Yu, L.-Z. Guo, Y.-F. Li, *On the Learnability of Test-Time Adaptation: A Recovery Complexity Perspective* In arXiv preprint arXiv:2605.28057, 2026.

Z.-H. Zhou, *A Brief Introduction to Weakly Supervised Learning* In National Science Review, 2018, vol. 5, no. 1, pp. 44–53.

L. Zhu, Z. Liu, S. Han, *Deep Leakage from Gradients* In Advances in Neural Information Processing Systems, 2019.

X. Zhu, Z. Ghahramani, J. Lafferty, *Semi-Supervised Learning Using Gaussian Fields and Harmonic Functions* In Proceedings of the Twentieth International Conference on Machine Learning, 2003, pp. 912–919.

A. Zou, Z. Wang, N. Carlini, M. Nasr, J. Z. Kolter, M. Fredrikson, *Universal and Transferable Adversarial Attacks on Aligned Language Models* In arXiv preprint arXiv:2307.15043, 2023.

周志华, 机器学习, 清华大学出版社, 2016, 1st ed.

李航, 统计学习方法, 清华大学出版社, 2019, 2nd ed.

邱锡鹏, 神经网络与深度学习, 机械工业出版社, 2020.

# 索引


一致，consistent，116
一致性约束，consistency regularization，60
一致收敛，uniform convergence，119
三元组损失，triplet loss，45
上下文学习，in-context learning，75
上下文老虎机问题，contextual bandit，58
下游任务，downstream task，63
不可知 PAC 可学习的，agnostic PAC learnable，95
不可知设定，agnostic setting，94
个体公平，individual fairness，352
主动学习，active learning，65
主成分分析，principal component analysis，27
二分类，binary classification，5
二分类交叉熵，binary cross-entropy，8
二次判别分析，quadratic discriminant analysis，47
交叉熵，cross-entropy，43
人口统计均等，demographic parity，348
人工智能，artificial intelligence，4
人类反馈强化学习，reinforcement learning from human feedback，379
代理损失，surrogate loss，41
任务，task，5
任务增量学习，task-incremental learning，69
优化，optimization，4
伪标签，pseudo-label，60
伪立方体，pseudo-cube，159
估计误差，estimation error，103
似然，likelihood，33
似然比攻击，Likelihood Ratio Attack，414
余弦相似度，cosine similarity，42
保真度，fidelity，400
信息抽取，information extraction，13
信息检索，information retrieval，15
信息泄漏，information leakage，21
灾难性遗忘，catastrophic forgetting，68
点估计，point estimation，34
点击率预测，click-through rate prediction，15
特征，feature，6
状态，state，56
独热表示，one-hot representation，43
独立同分布，independent and identically distributed，21，90
环境，environment，56
环境平均领域泛化，environment-average domain generalization，263，268
环境模型，environment model，57
生成，generation，19
生成式建模，generative modeling，32
生成式摘要，abstractive summarization，14
生成式问答，generative question answering，14
生长函数，growth function，122
监督学习，supervised learning，19，53
监督微调，supervised fine-tuning，378
目标域，target domain，72
目标域超额期望风险，target-domain excess expected risk，263
目标对齐，alignment，363
目标检测，object detection，14
直接偏好优化，direct preference optimization，380
直推学习，transductive learning，61
离线强化学习，offline reinforcement learning，58
积分梯度，integrated gradients，395
策略，policy，56
算法稳定性，algorithmic stability，169
类别增量学习，class-incremental learning，68
精确率，precision，22
系统辨识，system identification，17
累积局部效应，accumulated local effects，390
细胞类型识别，cell type identification，16
经验，experience，5
经验优化误差，empirical optimization error，105
经验风险，empirical risk，8

经验风险最小化，empirical risk minimization，8，97
经验高斯复杂度，empirical Gaussian complexity，131
结构化预测，structured prediction，13
结构风险最小化，structural risk minimization，105
结果监督，outcome supervision，370
统计学，statistics，4
缩放定律，scaling law，114
置信度，confidence，60
置换重要性，permutation importance，390
联邦学习，federated learning，78
联邦平均，federated averaging，78
聚类，clustering，18，54
能量分数，energy score，343
自然语言处理，natural language processing，13
自然语言推断，natural language inference，13
自监督学习，self-supervised learning，19，62
自训练，self-training，60
自适应共形推断，adaptive conformal inference，328
蒙特卡洛失活，Monte Carlo dropout，317
行为克隆，behavior cloning，58
行为测试，behavioral testing，299
行为约束，behavioral constraint，363
行动者—评论家，actor–critic，57
行动补救，algorithmic recourse，403
表征性伤害，representational harm，347
表示，representation，6
表示学习，representation learning，4
装袋法，bootstrap aggregating，137
观测，observation，56
规避攻击，evasion attack，434
视图，view，39，60
认知不确定性，epistemic uncertainty，315
训练，training，8
训练集，training set，6
评分预测，rating prediction，15
词元，token，62
词性标注，part-of-speech tagging，13
语义分割，semantic segmentation，14，70
语义匹配，semantic matching，13
语义熵，semantic entropy，310
语音合成，speech synthesis，17
语音处理，speech processing，17
语音识别，speech recognition，17
误差反向传播，error backpropagation，4
贝叶斯分类器，Bayes classifier，103
贝叶斯推断，Bayesian inference，34
贝叶斯风险，Bayes risk，102
负样本对，negative pair，64
负类，negative class，5
负迁移，negative transfer，72
责任主体，accountable role，301
超参数，hyperparameter，9
超额期望风险，excess risk，94，175
越狱，jailbreak，434
转化率预测，conversion rate prediction，16
输入，input，88
输入:，Input:，9
输出:，Output:，9
边界框，bounding box，14
边缘分布，marginal distribution，103
迁移学习，transfer learning，71
过参数化，overparameterization，222
过拟合，overfitting，12
过程监督，process supervision，370
近似误差，approximation error，103
适当评分规则，proper scoring rule，304，321
逆强化学习，inverse reinforcement learning，59
选择性标签，selective labels，347
选择性预测，selective prediction，322
逐点方法，pointwise approach，18
逐目标域领域泛化，target-wise domain generalization，263，268
逻辑函数，logistic function，7
部分依赖，partial dependence，389
重排序，reranking，16
间隔，margin，45
阈值，threshold，7，88
降维，dimensionality reduction，18，54
限制，restriction，122
随机响应，randomized response，418
随机平滑，randomized smoothing，336
随机森林，random forest，29
隐式偏差，implicit bias，241
隐私保护，privacy protection，409
隐藏分层，hidden stratification，297
集成学习，ensemble learning，50，136
零一损失，zero-one loss，41，89
零样本学习，zero-shot learning，73
非参数化模型族，nonparametric model family，27
非恰当学习，improper learning，87
非概率模型，non-probabilistic model，30
顿悟，grokking，114

预言机不等式，oracle inequality，108
预训练，pre-training，63
领域增量学习，domain-incremental learning，69
领域泛化，domain generalization，73
领域自适应，domain adaptation，72，263
风险接受，risk acceptance，301
验证集，validation set，6，105
高效学习，efficient learning，92
高斯判别分析，Gaussian discriminant analysis，32
高斯混合模型，Gaussian mixture model，31
鲁棒性，robustness，332

Brier 评分，Brier score，43

DBSCAN，density-based spatial clustering of applications with noise，50
DS 维，Daniely–Shalev-Shwartz dimension，148

$F_1$ 值，F1 score，22

KL 散度，Kullback–Leibler divergence，43
K 均值模型，K-means，27
*k* 近邻，*k*-nearest neighbors，28

Natarajan 维，Natarajan dimension，149

PAC 学习，probably approximately correct learning，92

Rényi 差分隐私，Rényi differential privacy，425

Schatten 范数，Schatten norm，231

候选召回，candidate retrieval，15
候选生成，candidate generation，15
假设，hypothesis，88
假设空间，hypothesis space，7，89
偏好学习，preference learning，80
偏差与复杂度的权衡，bias-complexity trade-off，104
偏置，bias，7
偶然不确定性，aleatoric uncertainty，315
元学习，meta-learning，74
元训练，meta-training，74
先验分布，prior distribution，34
公平性，fairness，345
共形分位数回归，conformalized quantile regression，327
共形预测，conformal prediction，326
关系抽取，relation extraction，13
关键点，keypoint，14
再生核希尔伯特空间，reproducing kernel Hilbert space，236
决策树，decision tree，28
准确率，accuracy，22
凝聚层次聚类，agglomerative hierarchical clustering，50
凸包，convex hull，136
分位数损失，pinball loss，318
分子性质预测，molecular property prediction，16
分子生成，molecular generation，16
分布变化，distribution shift，12
分布外检测，out-of-distribution detection，338
分布建模，distribution modeling，54
分布漂移，distribution drift，77
分布鲁棒优化，distributionally robust optimization，341
分类，classification，17
分类校准，classification calibration，204
分配性伤害，allocative harm，346
列表方法，listwise approach，18
判别式建模，discriminative modeling，32
副样本，ghost sample，123
半参数化模型，semiparametric model，29
半监督学习，semi-supervised learning，19，60
协方差，covariance，47
单次解释，local explanation，387
参数化模型族，parametric model family，27
参数稳定性，argument stability，188
双重下降，double descent，224
反事实解释，counterfactual explanation，393
变化应对能力，resilience to change，332
召回率，recall，22
可信保证，trustworthiness assurance，298
可信机器学习，trustworthy machine learning，291
可实现的，realizable，93
可扩展监督，scalable oversight，371
可监控性，monitorability，311
可解释性，interpretability，386
可计算 Natarajan 维，computable Natarajan dimension，165
可计算 PAC 可学习的，computably PAC learnable，143
可计算学习，computable learning，92
可识别性，identifiability，265
可靠性，reliability，314
合页损失，hinge loss，45
后门，backdoor，434
后验分布，posterior distribution，34
向量输出，vector output，39

命名实体识别，named entity recognition，13
回归，regression，13
图像分割，image segmentation，14
图像分类，image classification，14
图像处理，image processing，14
图像生成，image generation，14
图像重建，image reconstruction，14
图打散，graph shattering，155
图维，graph dimension，148
在线学习，online learning，77
均方误差，mean squared error，23
均等化赔率，equalized odds，349
垃圾信息检测，spam detection，13
域，domain，72
基于图的方法，graph-based methods，60
基于案例的解释，example-based explanation，393
基线，baseline，6
多任务学习，multi-task learning，70
多分类，multiclass classification，17
多标签分类，multilabel classification，17
多示例学习，multiple-instance learning，64
多臂老虎机问题，multi-armed bandit，58
多重校准，multicalibration，351
失效触发，invalidation trigger，301
奖励，reward，56
奖励投机，reward hacking，365
姿态估计，pose estimation，14
威胁模型，threat model，436
子群公平，subgroup fairness，349
学习排序，learning to rank，16
学习率，learning rate，9
学习算法，learning algorithm，10，90
学习范式，learning paradigm，19
安全屏蔽，shielding，374
实例分割，instance segmentation，14，70
宪法式人工智能，Constitutional AI，369
容量，capacity，27
对抗去偏，adversarial debiasing，358
对抗安全，adversarial security，433
对抗攻击，adversarial attack，433
对抗样本，adversarial example，434
对数几率，log-odds，35
对比学习，contrastive learning，64
对称化，symmetrization，124
少样本学习，few-shot learning，73
局部可解释模型无关解释，local interpretable model-agnostic explanations，394
嵌入，embedding，20
差分隐私，differential privacy，411
差分隐私随机梯度下降，differentially private stochastic gradient descent，419
干净标签投毒，clean-label poisoning，444
平均场理论，mean-field theory，252
平均稳定性，on-average stability，185
平均绝对误差，mean absolute error，23
广义加性模型，generalized additive model，388
广告，advertising，15
序列推荐，sequential recommendation，16
序列标注，sequence labeling，13
序列预测，sequence prediction，17
序贯决策，sequential decision making，16
应用场景，application scenario，17
度量学习，metric learning，45
异常暴露，outlier exposure，343
异常检测，anomaly detection，4
弱到强泛化，weak-to-strong generalization，371
弱学习，weak learning，94
弱监督学习，weakly supervised learning，63
强化学习，reinforcement learning，19，56
强学习，strong learning，94
归纳，induction，3
归纳偏置，inductive bias，8，89
归纳学习，inductive learning，61
影响函数，influence function，399
微调，fine-tuning，72
快速梯度符号法，fast gradient sign method，441

性能度量，performance measure，5
Ward 方法，Ward method，50
恰当学习，proper learning，87
情感分析，sentiment analysis，13
惰性训练，lazy training，234
意图识别，intent recognition，13
感知机，perceptron，35
成员推断，membership inference，410
成对方法，pairwise approach，18
成本敏感分类，cost-sensitive classification，359
批量学习，batch learning，77
折扣因子，discount factor，56
抽取式摘要，extractive summarization，13
持续学习，continual learning，19，68

损失，loss，89
损失函数，loss function，8，86
捷径学习，shortcut learning，334
排序，ranking，13
推理，inference，10
推荐，recommendation，14
提升，boosting，137
提示注入，prompt injection，434
插值，interpolation，222
搜索，search，15
支持向量，support vector，29
支持向量机，support vector machine，29
收缩引理，contraction lemma，129
故障诊断，fault diagnosis，17
教师集成的私有聚合，Private Aggregation of Teacher Ensembles，420
数据分布，data distribution，20
数据投毒，data poisoning，434
数据挖掘，data mining，4
数据集，dataset，6
整体代理，global surrogate，389
整体解释，global explanation，387
文本分类，text classification，13
文本摘要，text summarization，13
文本生成，text generation，13
文本聚类，text clustering，13
旁信息，side information，132
无监督学习，unsupervised learning，19，54
无监督领域自适应，unsupervised domain adaptation，72
智能体，agent，56
智能问答，question answering，13
最大似然估计，maximum likelihood estimation，34
最大类别概率，maximum softmax probability，342
有效 VC 维，effective VC dimension，144
期望泛化差，expected generalization gap，175
期望风险，expected risk，24
本地差分隐私，local differential privacy，412
朴素贝叶斯，naive Bayes，32
机会均等，equal opportunity，349
机器学习，machine learning，4
机器翻译，machine translation，13
机器遗忘，machine unlearning，425
权重，weight，7
条件作用，conditioning，3
条件生成，conditional generation，13
查询理解，query understanding，15
标注函数，labeling function，63
标签，label，5，88
标量输出，scalar output，39
校准，calibration，320
样本，sample，6
样本压缩，sample compression，132
样本压缩猜想，sample compression conjecture，135
样本复杂度，sample complexity，93
核回归，kernel regression，29
核方法，kernel method，38
核范数，nuclear norm，248
梯度下降，gradient descent，8
梯度动力学，gradient dynamics，241
梯度掩蔽，gradient masking，442
概念偏移，concept shift，264
概念漂移，concept drift，77
概念激活向量检验，testing with concept activation vectors，391
概念瓶颈模型，concept bottleneck model，391
概率主成分分析，probabilistic principal component analysis，31
概率分布输出，probability distribution output，40
概率图模型，probabilistic graphical model，34
概率推断，probabilistic inference，33
概率模型，probabilistic model，31
概率论，probability theory，4
模仿学习，imitation learning，19，58
模型，model，7
模型参数，model parameters，7
模型族，model family，25
模型无关元学习，model-agnostic meta-learning，74
模糊 C 均值，fuzzy c-means，49
欠拟合，underfitting，12
欠规定性，underspecification，297
正则化，regularization，12
正样本对，positive pair，64
正类，positive class，5
正预测值均等，predictive parity，350
没有免费的午餐，no-free-lunch，98
泛化，generalization，12
泛化差，generalization gap，90
测试时适应，test-time adaptation，73，343
测试集，test set，6，105
深度估计，depth estimation，70
深度学习，deep learning，4
深度集成，deep ensembles，317
混合增强，mixup，339

混淆矩阵，confusion matrix，22
源域，source domain，72
漂移检测，drift detection，338
演绎，deduction，3
激活函数，activation function，38