



MACHINE LEARNING NOTES

机器学习笔记

卷二：基础、理论和可信性

施晓罡

2026 年 · 第一版



MACHINE LEARNING NOTES

机器学习笔记

卷二：基础、理论和可信性

施晓罡

2026 年 · 第一版

机器学习笔记

MACHINE LEARNING NOTES

作者：施晓罡

版本：第一版

年份：2026

Copyright © 2026 施晓罡



Licensed under the Creative Commons Attribution-NonCommercial-NoDerivatives 4.0 International License (the "License");

You may not use this file except in compliance with the License.

You may obtain a copy of the License at

<https://creativecommons.org/licenses/by-nc-nd/4.0/>

Unless required by applicable law or agreed to in writing, software distributed under the License is distributed on an "AS IS" BASIS, WITHOUT WARRANTIES OR CONDITIONS OF ANY KIND, either express or implied. See the License for the specific language governing permissions and limitations under the License.





前言

本书目标

机器学习把数据、模型和计算连接起来，但理解一种方法，不能只记住模型名称或训练步骤。还需要知道模型能够表示什么规律，学习结论依赖哪些数据与假设，什么证据足以支持评价，以及方法进入具体应用和运行系统后会受到哪些约束。本书沿着这些联系组织内容，希望读者不仅会使用算法，也能解释一个结果为何成立、何时可信，以及怎样把它放入完整的技术过程。

本书面向已经具备基本微积分、线性代数、概率统计和编程基础，希望系统理解机器学习的读者。正文会在需要时回顾具体工具，但不以这些基础课程的完整讲解为目标。阅读后，读者应能从任务和证据出发比较模型与学习方式，并把理论条件、实验评价、应用要求和系统实现放在同一条推理链上考察。

本书内容

全书分为六卷。第一卷“数学准备”建立分析、代数、概率、离散结构与动态决策的共同语言。第二卷“基础、理论和可信性”说明学习如何发生、学习保证依赖哪些条件，以及可靠性、鲁棒性、公平性和隐私等可信要求应由什么证据支持。第三卷“模型”考察经典模型、神经网络模型和概率图模型的结构、推断与学习。第四卷“范式”转向经验和知识的获得方式，讨论交互反馈、有限标注以及任务变化下如何学习、复用和迁移知识。前四卷提供数学工具、分析依据和方法选择，后两卷把这些选择放入实际约束。第五卷“应用”围绕自然语言处理、图像处理、推荐与搜索，说明任务目标、数据形态、模型和评价方式如何相互制约。第六卷“系统”连接数据准备、训练计算、部署服务与运行维护，考察方法如何成为可持续运行的机器学习系统。这样的次序并不表示建模、应用和系统彼此割裂：应用需求决定评价口径，系统条件限制可用方法，而运行中的证据又会促使模型和学习过程重新调整。

参考资料

下面按内容列出可与本书配合阅读的教材。每本书的侧重点不同，读者可以根据正在阅读的卷和需要补充的问题选择查阅，不必按列表顺序通读。

综合与基础

- Mitchell 的 *Machine Learning* 从概念学习、归纳偏置和代表性算法出发，适合查阅机器学习的基本问题和早期统一框架。
- Bishop 的 *Pattern Recognition and Machine Learning* 将概率建模、决策理论、核方法和近似推断联系起来，适合查阅概率视角下的模型与推断方法。
- 周志华的《机器学习》覆盖常用模型、学习理论和实践问题，适合按任务比较方法的基本假设与用途。
- 李航的《统计学习方法（第2版）》以统计机器学习为定位，适合按模型查阅定义、算法和数学推导。
- Deisenroth、Faisal 和 Ong 的 *Mathematics for Machine Learning* 适合补充线性代数、解析几何、矩阵微积分、概率与优化等数学工具。

统计学习与学习理论

- Hastie、Tibshirani 和 Friedman 的 *The Elements of Statistical Learning* 适合查阅回归、分类、正则化、模型选择和统计学习方法。
- Shalev-Shwartz 和 Ben-David 的 *Understanding Machine Learning: From Theory to Algorithms* 适合查阅 PAC 框架、复杂度、泛化界与优化基础。
- Mohri、Rostamizadeh 和 Talwalkar 的 *Foundations of Machine Learning* 适合查阅学习界、核方法、在线学习及其理论保证。
- James、Witten、Hastie 和 Tibshirani 的 *An Introduction to Statistical Learning* 适合结合 R 实例理解回归、分类、重采样、正则化、树模型和无监督学习。

概率模型与图模型

- Murphy 的 *Machine Learning: A Probabilistic Perspective* 以概率视角组织监督学习、无监督学习、潜变量模型和图模型，适合查阅模型间的联系。

- Murphy 的 *Probabilistic Machine Learning: An Introduction* 适合查阅现代概率机器学习的统一记号、计算方法和模型实例。
- Murphy 的 *Probabilistic Machine Learning: Advanced Topics* 适合查阅深度生成模型、状态空间模型、贝叶斯优化和相关近似推断方法。
- Koller 和 Friedman 的 *Probabilistic Graphical Models: Principles and Techniques* 适合系统查阅图模型的表示、精确与近似推断以及参数和结构学习。
- Rasmussen 和 Williams 的 *Gaussian Processes for Machine Learning* 适合深入理解高斯过程、核函数、贝叶斯预测和超参数学习。

神经网络与深度学习

- Goodfellow、Bengio 和 Courville 的 *Deep Learning* 适合查阅神经网络表示、优化、正则化和深度生成模型。
- Bishop 和 Bishop 的 *Deep Learning: Foundations and Concepts* 从概率基础连接常用架构与训练方法，适合查阅相应概念和推导。
- 邱锡鹏的《神经网络与深度学习》适合查阅前馈、卷积、循环、注意力网络及其训练方法。
- Zhang、Lipton、李沐和 Smola 的 *Dive into Deep Learning* 适合结合可运行代码理解神经网络的实现、训练与调参过程。
- Géron 的 *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow* 适合查阅从数据准备、模型训练到评估和部署的实践流程。

强化学习

- Sutton 和 Barto 的 *Reinforcement Learning: An Introduction* 适合查阅马尔可夫决策过程、价值方法、策略方法与函数逼近。
- Szepesvári 的 *Algorithms for Reinforcement Learning* 适合查阅动态规划、Monte Carlo、时序差分和函数逼近算法的数学形式与分析。

应用与系统

- Manning、Raghavan 和 Schütze 的 *Introduction to Information Retrieval* 适合查阅文本表示、索引、检索模型和评价方法。
- Huyen 的 *Designing Machine Learning Systems* 从数据、训练、部署与监控讨论机器学习系统设计，适合查阅模型进入生产环境后的工程约束。

- Jurafsky 和 Martin 的 *Speech and Language Processing* 适合查阅自然语言与语音处理中的语言模型、序列标注、句法分析和语音识别。
- Szeliski 的 *Computer Vision: Algorithms and Applications* 适合查阅成像、特征、几何、识别与图像合成方法。
- Aggarwal 的 *Recommender Systems: The Textbook* 适合查阅协同过滤、基于内容的推荐、矩阵分解和推荐评价。
- Kleppmann 和 Riccomini 的 *Designing Data-Intensive Applications* 适合查阅存储、复制、分区、事务以及流式与批量处理的系统取舍。

上述教材的完整出版信息列于卷末参考文献。

数学符号

下表汇总全书反复使用的记号。各章若赋予符号更具体的含义，会在首次使用时另行说明。

对象与线性代数

对象	常用记号	含义
数集	$\mathbb{N}, \mathbb{Z}, \mathbb{R}, \mathbb{R}_+$	自然数集、整数集、实数集和非负实数集
集合与关系	$x \in A, A \subseteq B, A \cup B, A \cap B, A $	元素属于集合、子集、并集、交集和有限集合的基数
标量	$a, x, \lambda \in \mathbb{R}$	单个数值；小写斜体字母通常表示标量
向量	$\mathbf{x}, \mathbf{w} \in \mathbb{R}^d$	d 维向量；加粗小写字母表示向量
矩阵	$\mathbf{A} \in \mathbb{R}^{m \times n}, \mathbf{A}_{i,j}$	m 行 n 列矩阵及其第 i 行、第 j 列元素
数据与样本	$\mathcal{D} = \{(\mathbf{x}_i, y_i)\}_{i=1}^n$	含 n 个输入标签对的数据集；下标 i 表示样本索引
切片与迭代	$\mathbf{A}_{i,:}, \mathbf{A}_{:,j}, \mathbf{w}^{(t)}$	矩阵的第 i 行、第 j 列，以及第 t 次迭代的向量
Kronecker delta	$\delta_{i,j}$	当 $i = j$ 时取 1，否则取 0
矩阵变换	$\mathbf{A}^\top, \mathbf{A}^{-1}, \mathbf{A}^\dagger, \mathbf{I}_d, \text{tr}(\mathbf{A})$	转置、逆、伪逆、 d 阶单位矩阵和矩阵的迹
代数运算	$\langle \mathbf{x}, \mathbf{y} \rangle, \mathbf{x}^\top \mathbf{A} \mathbf{x}, \sum_i a_i, \prod_i a_i$	内积、二次型、求和与连乘
函数与模型	$f: \mathcal{X} \rightarrow \mathcal{Y}, h_{\mathbf{w}}(\mathbf{x})$	从输入空间到输出空间的函数，以及参数为 $\mathbf{w}$ 的模型
范数与距离	$\ \mathbf{x}\ _p, d(\mathbf{x}, \mathbf{y})$	p 范数与两对象之间的距离；具体定义由上下文给出

微积分与优化

对象	常用记号	含义
导数与梯度	$\frac{df}{dx}, \nabla_{\mathbf{w}} L(\mathbf{w})$	一元导数，以及标量值函数对参数向量的梯度
Jacobian 与 Hessian	$\nabla_{\mathbf{x}} \mathbf{f}, \nabla_{\mathbf{x}}^2 f$	向量值函数的一阶偏导矩阵，以及标量值函数的二阶偏导矩阵
渐近阶	$f(n) = \mathcal{O}(g(n))$	函数增长率的渐近上界
最优化	$\min_{\mathbf{w}} L(\mathbf{w}), \mathbf{w}^* \in \arg \min_{\mathbf{w}} L(\mathbf{w})$	最小目标值与取得最小值的参数；最大化使用 $\max$ 和 $\arg \max$

概率与信息论

对象	常用记号	含义
随机变量与实现	$X, \mathbf{X}, x, \mathbf{x}, p_X(x)$	随机标量、随机向量及其实现值； p_X 表示概率质量或密度函数
联合与条件概率	$p(x, y), p(x \mid y)$	随机变量实现值的联合概率与条件概率
边缘概率	$p(x) = \sum_y p(x, y), p(x) = \int p(x, y) \mathrm{d}y$	分别对离散变量求和或对连续变量积分得到的边缘概率
独立性与抽样	$X \perp Y, X \perp Y \mid Z, X_i \overset{\text{i.i.d.}}{\sim} p$	独立、给定 Z 条件独立，以及独立同分布抽样
矩与相关性	$\mathbb{E}[X], \text{Var}(X), \text{Cov}(X, Y)$	期望、方差和协方差
常用分布	$\text{Bernoulli}(p), \text{Cat}(\boldsymbol{\pi}), \mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma})$	伯努利分布、类别分布和多元高斯分布
事件指示函数	$\mathbb{I}\{A\}$	事件 A 成立时取 1，否则取 0
信息量	$H(p), H(p, q), \text{KL}(p\ q)$	熵、交叉熵和分布 p 相对于 q 的 KL 散度
概率正比关系	$p(\mathbf{x}) \propto q(\mathbf{x})$	忽略归一化常数时的概率正比关系

目录

第一部分	机器学习基础	1
第 1 章	引言	2
1.1	什么是机器学习	2
1.2	例子：垃圾邮件分类	5
1.3	任务	12
1.4	经验	20
1.5	性能度量	21
1.6	本章小结	23
第 2 章	模型简介	25
2.1	什么是模型	25
2.2	参数化方式与表示规模	27
2.3	变量的概率语义	30
2.4	变量的关系形式	36
2.5	输出的形式与含义	41
2.6	损失与学习准则	42
2.7	模型维度的交叉与组合	49
2.8	本章小结	53
第 3 章	学习范式简介	54
3.1	监督学习	55
3.2	无监督学习	56
3.3	强化学习	58
3.4	知识的高效利用	61
3.5	知识的演进与迁移	70
3.6	其他范式	80

3.7	范式的组合	83
3.8	本章小结	85
第二部分	机器学习理论	87
第 4 章	统计学习框架	88
4.1	学习问题	88
4.2	二分类问题	91
4.3	PAC 学习	95
4.4	学习的限制	101
4.5	模型选择	106
4.6	本章小结	113
第 5 章	二分类学习的可学习性	115
5.1	可实现的有限假设空间	115
5.2	不可知的有限假设空间	117
5.3	无限假设空间	122
5.4	估计期望风险	128
5.5	样本压缩	135
5.6	集成学习	139
5.7	可计算 PAC 学习	145
5.8	本章小结	149
第 6 章	多分类学习的可学习性	151
6.1	从二分类到多分类	151
6.2	有限标签空间	153
6.3	无限标签空间	158
6.4	可计算 PAC 学习	166
6.5	本章小结	170
第 7 章	一般学习的可学习性	171
7.1	一般学习问题	171
7.2	一致收敛	173
7.3	算法稳定性与可学习性	177
7.4	凸学习问题	200
7.5	非凸学习问题	206
7.6	本章小结	212

第 8 章	深度学习的可学习性	214
8.1	神经网络的学习问题	214
8.2	基于参数大小的可学习性	219
8.3	基于参数梯度初始值的可学习性	225
8.4	基于参数梯度更新的可学习性	232
8.5	基于参数分布的可学习性	242
8.6	理论的比较与使用	249
8.7	学习设定扩展的理论边界	251
8.8	本章小结	255
第 9 章	迁移学习的可学习性	257
9.1	迁移学习的学习问题	257
9.2	领域自适应的可学习性	264
9.3	领域泛化的可学习性	275
9.4	前沿研究	281
9.5	本章小结	283
第三部分	机器学习可信性	285
第 10 章	可信机器学习基础	286
10.1	技术可信性的范围与三个层次	287
10.2	系统属性与规范要求	291
10.3	证据能支持什么结论	293
10.4	威胁与生命周期治理条件	295
10.5	例子：邮件隔离的完整保证记录	297
10.6	本章小结	298
第 11 章	可靠性	300
11.1	不确定性的来源与估计	301
11.2	可靠性的检验	305
11.3	可靠性的保证	311
11.4	前沿研究	318
11.5	本章小结	319
第 12 章	鲁棒性	321
12.1	模型的鲁棒性	321

12.2	鲁棒性的检验	324
12.3	鲁棒性的增强	328
12.4	前沿研究	334
12.5	本章小结	335
第 13 章	公平性	337
13.1	模型的公平性	337
13.2	公平性的判定	340
13.3	公平性的干预	350
13.4	前沿研究	358
13.5	本章小结	359
第 14 章	目标对齐与行为约束	361
14.1	目标对齐与行为约束的基本概念	361
14.2	行为的评估与监督	365
14.3	行为泛化与约束保持的条件	372
14.4	行为干预	376
14.5	前沿研究	384
14.6	本章小结	385
第 15 章	可解释性	387
15.1	模型的可解释性	387
15.2	整体行为的解释	389
15.3	单次行为的解释	394
15.4	解释的质量	403
15.5	决策的补救	408
15.6	前沿研究	412
15.7	本章小结	413
第 16 章	隐私保护	415
16.1	隐私保护的基本概念	415
16.2	隐私保护的验证	418
16.3	隐私保护的实现	424
16.4	数据撤回与模型消除	431
16.5	前沿研究	437
16.6	本章小结	438

第 17 章	对抗安全	440
17.1	对抗安全的基本概念	440
17.2	脆弱性的评估	443
17.3	攻击防御与损害控制	455
17.4	前沿研究	463
17.5	本章小结	463
参考文献		465
索引		486

第一部分

机器学习基础

Machine Learning Basics

引言

1.1 什么是机器学习

1.1.1 什么是学习

儿童看过一些猫和狗以后，往往能认出一只从未见过的猫；学生练习解方程，也希望掌握的方法能用于新题。我们把这些变化称为“学习”，关心的不只是记住了哪些例子，还包括这些经验怎样改变了以后处理问题的能力。驾驶员根据路况和反馈改进操作，同样如此。一次疲劳造成的失误或短暂的兴奋也会改变当下表现，但谈论学习时，我们更关心由经验带来的、能够保持一段时间的变化。

这就留下了一个更具体的问题：计算机程序怎样利用有限经验形成处理新输入的规则，又该怎样检验这种能力？本章通过一个垃圾邮件分类案例回答这两个问题。沿着建模、训练、预测与评价的过程，我们将逐步认识任务、经验和性能度量，并区分“在已有样本上做得好”与“能够处理新样本”。有限经验在什么条件下足以支持可靠泛化，则留到机器学习理论部分讨论。

哲学很早就开始追问经验如何支持知识。**演绎** (deduction) 从给定前提出发，推出由前提保证的结论；**归纳** (induction) 则试图从有限的观察形成超出这些观察的一般判断。D. Hume (休谟) 指出，过去经验本身并不能以演绎方式保证未来仍与过去相似¹。机器学习同样面对这个问题：训练数据永远只是已经见过的有限情形，系统却被要求处理尚未见过的输入。机器学习系统要作出这种判断，必然还依赖关于哪些规律值得延伸到新情形的假设。

要研究这种变化，还需要决定观察什么。心理学既研究可见的行为变化，也研究经验如何改变内部知识与表征，即学习者组织和理解信息的方式。**条件作用** (conditioning) 关注刺激、反应和结果之间逐渐形成的联系，例如某种行为得到奖励后，发生频率可能增加；认知取向则进一步讨论记忆、概念和策略如何改变。不同定义强调的对象并不相同，因此不能把学习简单等同于“记住更多事实”。一种有影响的功能性定义把学习理解为

¹ D. Hume, *An Enquiry Concerning Human Understanding*, 1748

环境中的规律所引起的行为改变²。。

1.1.2 从学习到机器学习

机器学习 (machine learning, ML) 借用了“从经验中改变”的核心直觉, 但机器没有必要复制人的心理过程。对计算机程序而言, 更直接的问题是: 如果逐条编写规则过于困难, 能否让程序利用已有数据或交互反馈, 自动形成一套在新输入上也有效的处理方法? 例如, 垃圾邮件的写法不断变化, 维护一张完整的关键词和例外规则清单很快就会变得困难; 历史邮件却提供了大量可以利用的经验。

这一设想不是在某一年突然形成的, 而是由神经科学、计算理论、统计推断和自动控制等多条研究路线逐渐汇合而来。1943 年, W. S. McCulloch 和 W. Pitts 用理想化神经元组成网络, 说明简单单元的连接可以表达逻辑运算, 为后来以连接结构实现计算和学习提供了早期形式化模型³。。A. M. Turing (图灵) 随后在讨论机器智能时提出, 可以从一个类似儿童的初始机器出发, 通过教育和经验改变它, 而不是直接写出成人智能的全部规则⁴。。

20 世纪 50 年代, 研究者开始把这种设想落实为能够根据样本调整内部数值的程序。F. Rosenblatt 提出 **感知机** (perceptron), 让一个简单的神经网络根据分类错误调整连接权重, 也就是改变各项输入对判断结果的影响⁵。。1959 年, A. L. Samuel 在跳棋程序的研究中把“机器学习”写入论文标题, 展示程序如何利用已存棋局和自我对弈改进评价局面的能力⁶。。这两项工作分别体现了从带答案的样本中调整分类规则, 以及从博弈经验中改进决策评价; 它们已经呈现出后来监督学习与交互学习的不同经验形式。

有了能从样本中调整的程序, 还需要回答两类问题: 它为什么可能适用于新样本, 又该怎样高效地调整更复杂的模型? V. N. Vapnik 和 A. Y. Chervonenkis 等人的工作研究有限样本与候选规则复杂程度之间的关系, 为分析规则能否推广到新样本提供了理论工具⁷。。1980 年代, **误差反向传播** (error backpropagation) 被用于训练多层网络: 从输出端的误差出发, 逐层计算各参数对误差的影响, 为调整参数提供依据⁸。。进入 21 世纪后, 更大规模的数据、计算资源和模型共同推动了**表示学习** (representation learning), 即让模型从数据中学会提取后续任务需要的信息。**深度学习** (deep learning) 利用多层变换形成这样的表示, 在语音、视觉和自然语言等任务中把特征学习与预测结合起来⁹。。这些路线分别推进了理论分析和计算方法, 仍在共同回答开篇的问题: 怎样把有限经验转化为处理新情形的能力?

机器学习位于多个领域的交汇处。它与**人工智能** (artificial intelligence, AI) 关系最直接: 人工智能关心怎样构造能够感知、推理、决策和行动的

² J. De Houwer, D. Barnes-Holmes, A. Moors, *What Is Learning? On the Nature and Merits of a Functional Definition of Learning* In *Psychonomic Bulletin & Review*, 2013, vol. 20, no. 4, pp. 631–642

³ W. S. McCulloch, W. Pitts, *A Logical Calculus of the Ideas Immanent in Nervous Activity* In *The Bulletin of Mathematical Biophysics*, 1943, vol. 5, pp. 115–133

⁴ A. M. Turing, *Computing Machinery and Intelligence* In *Mind*, 1950, vol. 59, no. 236, pp. 433–460

⁵ F. Rosenblatt, *The Perceptron: A Probabilistic Model for Information Storage and Organization in the Brain* In *Psychological Review*, 1958, vol. 65, no. 6, pp. 386–408

⁶ A. L. Samuel, *Some Studies in Machine Learning Using the Game of Checkers* In *IBM Journal of Research and Development*, 1959, vol. 3, no. 3, pp. 210–229

⁷ V. N. Vapnik, A. Y. Chervonenkis, *On the Uniform Convergence of Relative Frequencies of Events to Their Probabilities* In *Theory of Probability and Its Applications*, 1971, vol. 16, no. 2, pp. 264–280

⁸ D. E. Rumelhart, G. E. Hinton, R. J. Williams, *Learning representations by back-propagating errors* In *Nature*, 1986, vol. 323, no. 6088, pp. 533–536

⁹ Y. LeCun, Y. Bengio, G. Hinton, *Deep Learning* In *Nature*, 2015, vol. 521, pp. 436–444

系统，机器学习则提供了让系统从经验获得部分能力的方法。搜索、规划或逻辑推理可以在没有参数学习的情况下工作，而一个学习模型也可能只完成很窄的预测任务。因此，机器学习是人工智能的重要技术路径，却不能代替人工智能所研究的全部问题。

数据挖掘（data mining）关注从大量数据中发现有用的模式、关系和异常，并将发现转化为可理解或可使用的知识。例如，分析交易记录可以发现经常一起购买的商品，也可以识别不同的顾客群体或异常交易。机器学习为数据挖掘提供判断类别、寻找群组和**异常检测**（anomaly detection）等方法，其中异常检测用于识别明显偏离通常模式的记录。数据挖掘通常还包括数据收集与清理、模式解释、可视化以及领域验证等环节。两者有很大的重叠，但关注点有所不同：机器学习更强调如何从经验得到能够预测或决策的模型，以及模型能否用于新数据；数据挖掘更强调如何从已有数据中获得值得关注的规律。在实际研究和应用中，这一界限并不严格。

统计学（statistics）和**概率论**（probability theory）提供了从有限观测讨论不确定性、估计总体规律和检验结论的语言。训练样本为何具有代表性、参数估计有多大误差、测试结果能否推广，都离不开统计思想。机器学习还特别关心预测算法在高维数据和大规模计算下是否可行，以及模型能否从文本、图像等复杂输入中自动形成有用的表示。两者在方法上大量重叠，研究问题和评价重点并不总是相同。

要让程序改善预测，还需要把“好不好”变成可计算的目标。**优化**（optimization）研究如何在候选解中寻找使目标函数较小或较大的方案。例如，用一个数衡量预测错误的代价，训练就可以尝试寻找让这个数变小的参数。但即使已有样本上的错误很少，也不能保证模型在新数据上表现良好。算法与复杂性理论研究计算需要多少时间和存储，数据库与分布式系统负责可靠地组织数据和计算，硬件结构则决定哪些模型能够在现实资源约束下训练和部署。这些计算机科学问题会直接改变一种学习方法是否可用。

机器学习还从信息论、信号处理、控制理论、认知科学和神经科学中吸收概念。信息论帮助刻画信息与压缩，信号处理提供处理语音、图像和时序信号的表示方法，控制理论研究带反馈的动态系统；认知科学和神经科学则不断提供关于感知、记忆与适应的启发。与此同时，医学、金融、教育等应用领域决定标签意味着什么、错误代价如何衡量以及哪些约束必须满足。一个实际机器学习问题因此不只是“选一个模型”，还需要把领域目标、数据生成过程、学习算法和评价方式共同规定清楚。

1.1.3 机器学习的定义

这些研究路线都谈到“从经验中改进”，但要判断一个程序是否真的学到了东西，还必须说明它在做什么、用什么衡量改进，以及利用了哪些经验。

T. M. Mitchell 的经典定义把这三点明确联系起来¹⁰。。

¹⁰ T. M. Mitchell, *Machine Learning*, McGraw-Hill, 1997, 1st ed.

定义 1.1 机器学习 对于某类任务 T 和性能度量 P ，如果一个计算机程序在任务 T 上按 P 衡量的性能因经验 E 而有所改善，就称该程序从经验 E 中进行了学习。

定义 1.1 中的三个要素各有具体含义：

- **任务** (task, T) 说明希望系统完成什么，例如判断邮件是否为垃圾邮件；
- **性能度量** (performance measure, P) 说明怎样判断任务完成得好不好，例如分类正确的比例或漏放垃圾邮件的数量；
- **经验** (experience, E) 说明系统从什么信息中学习，例如带人工标签的历史邮件，也可以是没有标签的数据、用户反馈或与环境交互得到的奖励。

三个要素必须放在一起理解。同一批邮件可以支持垃圾邮件分类，也可以用于发现邮件主题；同一个分类器按准确率衡量可能表现良好，按误拦正常邮件的代价衡量却未必合格。“因经验 E 而有所改善”也不意味着每增加一个样本，指标都要单调上升。经验 E 可以是一批已标注样本、交互记录或其他反馈；定义要求用 P 检验这些经验是否改善了任务表现，而不是把 E 解释成必须逐步增加的样本数量。

1.2 例子：垃圾邮件分类

回到垃圾邮件的问题。逐条维护拦截规则很难覆盖不断变化的写法，我们希望利用已经判定类别的历史邮件，学出一套处理新邮件的规则。本节沿着数据准备、建模、训练、预测和评估展开这个过程。邮件和标签均为教学构造，计算结果由可复现脚本生成，不代表真实邮件系统的效果。

我们希望根据一封邮件中可用的信息，将它判为垃圾邮件或正常邮件。这是一个 **二分类** (binary classification) 问题，即从两个候选类别中选择一个。用**标签** (label) 记录每封邮件的已知类别：约定垃圾邮件是**正类** (positive class)，标签为 1；正常邮件是**负类** (negative class)，标签为 0。正负只是计数和计算时的约定，不表示类别的好坏。表 1.1 把三个要素落实到这个问题中。

评价学习结果需要参照物。**基线** (baseline) 就是用来比较的简单方案；本例把所有邮件都判为训练集中较多的类别，也就是正常邮件。如果测试集中大多数邮件是正常邮件，这个办法即使完全没有识别垃圾邮件，也可能得到不低的准确率。因此，后面既要与基线比较，也要分别检查两类错误。

要素	在垃圾邮件分类中的含义
任务 T	输入一封邮件，输出“垃圾邮件”或“正常邮件”。
性能度量 P	考察测试邮件中分类正确的比例，并分别记录误拦正常邮件和漏放垃圾邮件。
经验 E	历史邮件、由人工给出的类别标签，以及据此形成的训练反馈。

表 1.1 垃圾邮件分类问题的任务、性能度量与经验。三个要素共同规定了“学得更好”的含义。

编号	子集	邮件片段	x_1	x_2	y	类别
tr01	训练	“限时优惠，立即领取……”	3	2	1	垃圾邮件
tr06	训练	“周会改至下午三点”	0	0	0	正常邮件
tr11	训练	“优惠券报销说明”	2	0	0	正常邮件
va02	验证	“会员权益，详情见链接”	1	2	1	垃圾邮件
va03	验证	“本周三场促销培训”	3	0	0	正常邮件
te02	测试	“两项优惠，见附件链接”	2	1	0	正常邮件
te07	测试	“专属优惠今日有效”	2	0	1	垃圾邮件
te08	测试	“优惠详情见两个链接”	1	2	0	正常邮件

表 1.2 教学数据的部分样本。 x_1 为促销提示词次数， x_2 为外部链接数，标签 $y = 1$ 表示垃圾邮件。训练集、验证集和测试集承担不同职责。

1.2.1 从邮件到样本与特征

计算机需要从邮件中读取具体信息，才能作出“是否可疑”的判断。我们把原始邮件转换成模型可以处理的**表示**（representation），也就是约定用哪些量描述它。这些量称为**特征**（feature）。可用信息包括发件人及其域名、主题和正文中的词语、字符组合、链接与附件、邮件头、发送时间以及用户过去是否与发件人通信。现实系统通常需要综合多类信息，也不能预先认定某一个特征在所有环境中都可靠。

为了让数据和计算能够手工复核，本例作一个有意简化的假设：垃圾邮件标签与两个计数特征密切相关。令 x_1 为正文中促销提示词出现的次数， x_2 为外部链接的数量，一封邮件便表示为特征向量 $\boldsymbol{x} = (x_1, x_2)^T \in \mathbb{R}^2$ 。这个假设只服务于教学案例；它省略了发件人身份、上下文和附件内容等信息，不能据此推断真实垃圾邮件只由这两个特征决定。

在这个带标签的案例中，一封邮件的特征与标签组成一个**样本**（sample） $(\boldsymbol{x}_i, y_i)$ ，即一次可供学习的记录；下标 i 标识第 i 封邮件。多个样本组成**数据集**（dataset）。表 1.2展示了数据的一部分。原始文本和特征向量是不同层次的对象：前者是现实中收集的信息，后者是为当前模型构造的输入。

如果反复用同一批邮件学习、挑选方案和报告成绩，就难以判断模型能否处理真正的新邮件。为此，在开始训练前，把历史数据划分为**训练集**（training set）、**验证集**（validation set）和**测试集**（test set）：分别用来学习参数、选择训练轮数等配置，以及在选择完成后评价结果。表中的“子集”一列记录了这项分工。需要从数据估计的预处理规则也只用训练集确定，例如根据词频选择词表，或计算用于调整特征尺度的均值。否则，后

面的评价已经提前利用了本应保留的信息。

1.2.2 对问题进行建模

要从有限的邮件样本得到可用于新邮件的分类器，必须先对特征与结果之间的关系作出假设。这里假设垃圾邮件倾向可以由两个特征的线性组合描述：促销提示词或链接数量每增加一个单位，都会使得分改变一个由相应权重决定的量。得分没有固定的取值范围，不能直接当作概率。我们再用**逻辑函数**（logistic function）将它映射到 $(0, 1)$ ：得分越大，输出越接近 1；得分越小，输出越接近 0。这个计算关系写为

$$z_i = b + w_1 x_{i,1} + w_2 x_{i,2}, \quad (1.1)$$

$$\hat{p}_i = \sigma(z_i) = \frac{1}{1 + \exp(-z_i)}. \quad (1.2)$$

这个分类**模型**（model）规定输入怎样产生输出。其中， $\hat{p}_i$ 解释为模型对“第 i 封邮件是垃圾邮件”的概率估计。式中的 $\exp(-z_i) = e^{-z_i}$ 是指数函数； σ 是逻辑函数的简写。概率还需要转换成类别：当 $\hat{p}_i \geq 0.5$ 时预测 $\hat{y}_i = 1$ ，否则预测 $\hat{y}_i = 0$ 。这里的 0.5 就是分类**阈值**（threshold），决定多大的垃圾邮件概率会触发拦截。

b 是**偏置**（bias），决定两个特征都为零时的得分； w_1, w_2 是特征的**权重**（weight），分别决定多一个促销词或外部链接会使得分改变多少。这些需要从数据中确定的量称为**模型参数**（model parameters），合写为 $\theta = (b, w_1, w_2)^T$ ，并将概率输出记为 $f_{\theta}(\mathbf{x}_i) = \hat{p}_i$ 。每一组参数都确定一条具体的分类规则，所有允许参数产生的函数关系共同组成**假设空间**（hypothesis space）。选择式 (1.2) 这样的函数形式，与在训练中确定某个具体的 θ ，是两个不同决定：前者规定可以考虑哪些模型，后者从中选出一个具体模型。

有限样本通常不能唯一决定对所有新邮件的预测。我们先对两个计数特征线性加权得到得分，再用逻辑函数和固定阈值确定分类，这些预先作出的选择构成**归纳偏置**（inductive bias）。归纳偏置让学习算法优先考虑某一类规律，使从有限经验推广到未见样本成为可能，同时也限制了模型能表达的关系。本例只保留两个计数；即使两封邮件的语境完全不同，只要计数相同，模型就会给出相同预测。若区分它们需要发件人或上下文信息，调整权重也无法补回输入中已经丢失的内容。

有了候选的分类规则，还需要比较哪一组参数预测得更好。**损失函数**（loss function）给一次预测的错误程度计分，损失越小，表示这次预测越符合目标。本例输出的是概率，因此采用**二分类交叉熵**（binary cross-entropy）：它检查模型给真实类别分配了多少概率，分配得越少，惩罚越大。对于标

签 $y_i \in \{0, 1\}$, 损失写为

$$\ell(\hat{p}_i, y_i) = -y_i \log \hat{p}_i - (1 - y_i) \log(1 - \hat{p}_i). \quad (1.3)$$

这里 $\log$ 取自然对数。以一封真正的垃圾邮件为例, 它的标签为 $y_i = 1$, 损失为 $-\log \hat{p}_i$ 。如果模型预测它是垃圾邮件的概率为 0.9, 损失约为 0.105; 如果预测概率只有 0.1, 损失则约为 2.303。因此, 模型为邮件的真实类别分配的概率越高, 损失越小; 概率越低, 损失越大。

只比较一封邮件不足以选择参数。若训练集包含 n 个样本, 我们把各次预测的损失取平均, 得到**经验风险** (empirical risk), 用它概括模型在整批训练邮件上的错误代价:

$$\hat{R}_{\text{train}}(\theta) = \frac{1}{n} \sum_{i=1}^n \ell(f_{\theta}(\mathbf{x}_i), y_i). \quad (1.4)$$

在允许的参数中寻找平均训练损失最小的一组, 称为**经验风险最小化** (empirical risk minimization, ERM)。如果最小值能够取到, 这个目标可以写为

$$\hat{\theta} \in \arg \min_{\theta} \hat{R}_{\text{train}}(\theta). \quad (1.5)$$

这里的 $\arg \min$ 表示使目标函数达到最小值的参数集合; 实际训练往往只是在有限计算内寻找较好的近似解。损失函数服务于参数学习, 性能度量服务于任务评估, 二者可以一样, 也可以不同。本例用交叉熵来训练模型, 但最终对整个任务的结果进行评估还要看在测试数据上的准确率、误拦数和漏放数等指标。

1.2.3 根据历史邮件进行训练

目标已经写出, 但计算机仍需要知道怎样调整参数。**训练** (training) 就是利用训练数据确定参数的过程。本例采用**梯度下降** (gradient descent): 在当前参数附近, 沿着损失下降的方向走一小步, 然后重新计算并继续调整。从 $\theta^{(0)} = (0, 0, 0)^T$ 开始, 更新规则为

$$\theta^{(t+1)} = \theta^{(t)} - \eta \nabla_{\theta} \hat{R}_{\text{train}}(\theta^{(t)}). \quad (1.6)$$

上标 (t) 表示第 t 次更新后的参数; ∇_{θ} 表示对参数求梯度。梯度指向损失在当前位置增长最快的方向, 所以更新时沿它的反方向移动。**学习率** (learning rate) η 控制每一步的幅度, 本例取 $\eta = 0.35$ 。本例的损失函数具有连续的导数, 沿非零梯度的反方向走足够小的一步会使损失下降; 步子过大则未必如此。

权重和偏置由式 (1.6) 更新, 学习率和迭代次数却需要另外选择。这类控制模型或学习过程的配置称为**超参数** (hyperparameter)。分类阈值也要

事先约定或通过验证集选择，不过在本例中，它只影响概率怎样变成类别，不参与交叉熵的参数更新。

算法 1.1 垃圾邮件分类器的训练

输入： 训练集 D_{train} ，验证集 D_{val} ，学习率 η ，候选迭代次数集合 C

输出： 选定参数 $\hat{\theta}$

```

1: 初始化  $\theta^{(0)}$ 
2: for  $t = 0, \dots, \max(C) - 1$  do
3:   在训练集上计算经验风险及其梯度
4:   按式 (1.6) 得到  $\theta^{(t+1)}$ 
5:   if  $t + 1 \in C$  then
6:     在验证集上记录分类性能
7:   end if
8: end for
9: 从验证性能最好的候选中选择较早的一个，记为  $\hat{\theta}$ 
10: return  $\hat{\theta}$ 

```

第一次更新把三个参数从零改为约 $(-0.029, 0.102, 0.058)^T$ ，平均训练损失随之从 0.693 降至 0.658。这说明更新改善了训练集上的预测，但还没有回答应当训练多久。本例事先选定 20、40 和 60 次参数更新作为比较的候选时点：每到一个时点，就保存当时的三个参数，并用它们对验证集中的 6 封邮件进行分类。这样得到的是同一种模型在三个训练阶段的版本。验证集中的邮件不参与参数更新，只用于比较这些版本的分类效果。

完成 20 次和 40 次参数更新后，模型都正确分类了 6 封验证邮件中的 5 封，准确率均为 5/6；完成 60 次更新后，模型只正确分类了 4 封，准确率为 4/6。我们事先约定：验证准确率相同时，选择参数更新次数较少的版本。因此，最终采用第 20 次更新后保存的参数，而不是训练结束时的最后一组参数。选定参数为

$$\hat{\theta} = (-1.000, 0.692, 0.230)^T. \quad (1.7)$$

t	$b^{(t)}$	$w_1^{(t)}$	$w_2^{(t)}$	训练损失
0	0.000	0.000	0.000	0.693
1	-0.029	0.102	0.058	0.658
20	-1.000	0.692	0.230	0.452

表 1.3 训练过程中参数与平均训练损失的变化。第 20 次迭代是验证集选定的检查点；表中数值由完整计算结果舍入得到。

图 1.1 显示，继续训练仍会降低训练集损失，验证集交叉熵也缓慢下降，但按 0.5 阈值计算的验证准确率并不因此持续提高。这说明，优化的损失与最终关心的性能度量有关联，却不是同一个量。

回看这次训练，模型形式、学习算法和训练结果承担了不同工作。




图 1.1 训练集和验证集上的平均交叉熵损失。蓝色实线表示训练曲线，红色虚线表示验证曲线，黄色竖线标出按验证准确率选定的第 20 次迭代；模型选择并非直接读取训练损失的最低点。

式 (1.2) 规定特征怎样转换为概率，尚未给定其中的参数；**学习算法** (learning algorithm) 则规定怎样利用数据确定参数。本例的算法包括梯度更新和验证选择两个环节，具体过程见算法 1.1。把选出的参数代入模型形式，才得到可以直接预测的具体函数。此后每收到一封新邮件，只需计算这个函数，无须重做训练。

1.2.4 对新邮件进行预测

参数选定后，就可以处理新的输入了。使用学到的模型计算输出，称为**推理** (inference)。本例的推理依次计算垃圾邮件概率和预测类别，不需要把真实标签作为输入，也不更新模型参数。它既可以用于尚无标签的新邮件，也可以用于已有标签的测试邮件；后一种情况只是让我们能在预测之后检查答案。

对于编号为 new01 的新邮件，其特征为 $\mathbf{x} = (2, 2)^T$ ，代入选定参数得到

$$z = -1.000 + 0.692 \times 2 + 0.230 \times 2 = 0.844, \quad (1.8)$$

$$\hat{p} = \sigma(0.844) = 0.699. \quad (1.9)$$

因为 $0.699 \geq 0.5$ ，模型把它预测为垃圾邮件。表 1.4 列出三个新样本的结果。

编号	邮件片段	(x_1, x_2)	$\hat{p}$	阈值	预测
new01	“会员优惠，点击两个链接”	(2, 2)	0.699	0.5	垃圾
new02	“项目文档见共享链接”	(0, 1)	0.316	0.5	正常
new03	“优惠详情见两个链接”	(1, 2)	0.538	0.5	垃圾

表 1.4 新邮件的推理结果。概率和类别均由式 (1.7) 中的固定参数计算；真实标签不是推理所需的输入。

训练与推理必须使用相同的特征定义和预处理顺序。如果训练时 x_1 统计某个固定词表，推理时就不能在看到新邮件后任意改换词表。部署系统还需要保存模型参数、特征规则和阈值，仅保存参数向量通常不足以复现预测。

1.2.5 模型的评估

算出了预测，不等于知道预测是否正确。为检验效果，我们取出此前保留的、带真实标签的测试邮件，在模型和阈值都已固定后计算预测，再将预测类别与标签逐一比较。表 1.5 列出了本例全部 8 封测试邮件的结果；测试标签只在这一步用于评价，不回头参与参数更新或配置选择。

编号	(x_1, x_2)	y	$\hat{p}$	$\hat{y}$	结果
te01	(3, 2)	1	0.823	1	识别垃圾邮件
te02	(2, 1)	0	0.649	1	误拦正常邮件
te03	(1, 3)	1	0.594	1	识别垃圾邮件
te04	(0, 0)	0	0.269	0	放行正常邮件
te05	(0, 2)	0	0.368	0	放行正常邮件
te06	(1, 0)	0	0.424	0	放行正常邮件
te07	(2, 0)	1	0.595	1	识别垃圾邮件
te08	(1, 2)	0	0.538	1	误拦正常邮件

表 1.5 独立测试集上的逐样本预测。测试标签只用于比较，不参与参数、迭代次数或阈值的选择。

模型正确分类 6 封邮件，准确率为 $6/8 = 75\%$ ；它识别出全部 3 封垃圾邮件，但误拦了 2 封正常邮件。始终预测“正常”的基线正确分类 5 封，准确率为 62.5%，不会误拦，却漏掉全部 3 封垃圾邮件。模型是否比基线更有用，取决于应用怎样权衡这两类错误。

方法	准确率	误拦数	漏放数
学到的线性模型	75.0%	2	0
全部预测为正常	62.5%	0	3

表 1.6 学到的模型与基线在同一测试集上的比较。单个指标不能完整表达两类错误的代价。

这次评价关心的是**泛化** (generalization)：从已有样本学到的规则，能否用于未参与学习的新样本。模型若过度迎合训练样本中的偶然细节，训练表现很好，却在同一来源的新样本上明显变差，就出现了**过拟合** (overfitting)。反过来，模型若连数据中的主要规律都未能学到，训练和新样本上的表现都不好，则可能是**欠拟合** (underfitting)。训练不足或模型表达能力不足都可能造成欠拟合，不能只凭一次测试成绩判断原因。

降低训练损失与改善泛化因此是两个需要分别检查的问题。为了减少过度迎合训练样本的倾向，可以采用**正则化** (regularization)，例如在训练目标中加入对过大权重的惩罚，使选择参数时同时考虑拟合程度和模型

约束。这种约束是否合适，仍需通过验证数据检查。

如果垃圾邮件发送者改变措辞、用户群体发生变化，或者收集训练邮件的渠道与部署环境不同，训练数据与新数据的关系就可能改变。这种**分布变化**（distribution shift）是指数据出现的规律发生了变化，会使过去的测试结果失去代表性。此时，即便模型没有过拟合旧数据，也可能需要补充新数据、调整输入表示或重新训练。持续监测部署表现，才能发现原先的评价何时已经不再适用。

至此，历史邮件已经经过表示、训练和选择，变成一个能够预测新邮件的模型；独立测试又揭示了它会犯哪些错误。接下来的问题是：换一种应用，这些环节中哪些要求会改变？下面从任务、数据和性能度量三个方面，把这个案例中的选择推广到更一般的情形。

1.3 任务

“分析用户评论”还不是一个足够明确的任务。我们可能想判断用户是否满意，也可能只想提取评论中的产品名称，或者把大量评论概括成一段摘要。输入材料相近，需要的结果却不同。因此，任务必须说清输入是什么、输出是什么，以及怎样才算完成得好。带着这三个问题观察文本、图像、推荐与搜索应用，就能看出哪些问题可以用相似的方法处理，哪些需要不同的建模方式。

1.3.1 应用场景中的任务

自然语言处理 用户向客服发来一句话，系统可能需要判断他想办理什么、找出订单信息，也可能需要写出答复。这些工作属于**自然语言处理**（natural language processing, NLP），即用计算方法分析和生成人类语言。这里以文本为例，观察输出要求怎样决定任务形式。

文本分类（text classification）为文本赋予预先规定的类别。**情感分析**（sentiment analysis）判断评论表达的态度，例如将“送货很快，包装也完好”判为正面评价；**垃圾信息检测**（spam detection）识别邮件或消息中的垃圾内容；**意图识别**（intent recognition）判断用户想做什么，例如把“我的订单什么时候到”归入物流查询。这三项任务都可以通过分类完成。**文本聚类**（text clustering）则在没有预先给定类别答案的情况下，按内容相似性组织文本。例如，分析一批用户反馈时，可以先形成若干群组，再观察各组是否对应物流、价格或质量等主题。分类使用给定的类别体系，聚类用于探索数据中的分组结构。

有时，整句话的类别还不够，还需要判断其中各个位置的作用。**序列标注**（sequence labeling）为文本中的各个位置赋予标签。例如，**词性标注**（part-of-speech tagging）判断每个词是名词、动词还是其他词类；**命名实**

体识别 (named entity recognition) 找出人名、机构名、地名等片段并判断其类型，也常用序列标注完成。

处理订单或人物信息时，我们还希望把这些片段整理成可直接使用的记录。**信息抽取** (information extraction) 从文本中提取实体、关系等结构化信息。例如，从“小林就职于星海公司”中识别人名和机构名后，**关系抽取** (relation extraction) 进一步确定二者的任职关系，可以建模为对实体对的关系分类。序列标注以及这类联合抽取任务的输出包含相互关联的部分，属于**结构化预测** (structured prediction)：需要预测一个有内部关系的整体，而不只是单个类别。

同一个诉求也可能有不同说法。客服系统需要判断“如何退货”和“商品不想要了怎么退”是否可以使用同一份答复。**语义匹配** (semantic matching) 就是比较文本的含义，判断两段话是否意思相近，或查询与文档是否相关。输出“匹配或不匹配”时，这是分类任务；若输出一个连续数值来估计相似程度，则可以作为**回归** (regression) 任务；按相关程度排列文档时，则形成**排序** (ranking) 任务，即确定候选的相对次序。**自然语言推断** (natural language inference) 进一步判断两段陈述之间的逻辑关系，通常分为蕴含 (entailment)、矛盾 (contradiction) 和中性 (neutral) 三类，分别表示前一陈述支持后一陈述、两者冲突，或信息不足以确定。例如，“有人在雨中跑步”蕴含“有人在户外活动”。

找到相关资料以后，系统还可能需组织一段答复。**文本生成** (text generation) 负责产生符合输入要求的新文本。**机器翻译** (machine translation) 在保留原意的基础上，将一种语言的文本转换为另一种语言；**文本摘要** (text summarization) 从长文档中保留重要信息，形成较短的概述；**智能问答** (question answering) 根据问题和可用资料组织答案。这些任务都可以采用**条件生成** (conditional generation)，即在给定输入的条件下产生输出。它们也有其他任务形式：直接选择原文句子的**抽取式摘要** (extractive summarization) 可以建模为句子分类或排序，从材料中选取答案片段的问答则属于信息抽取。与之对应，**生成式摘要** (abstractive summarization) 和**生成式问答** (generative question answering) 需要模型自行组织输出文字。

图 1.2 用同一句输入说明不同文本任务所要求的输出。意图识别只给出整句话的类别，信息抽取定位并标记其中的实体，答案生成则产生新的文本序列。

图像处理 把输入换成照片，同样需要明确希望得到什么结果。相册管理可能只需要知道照片拍的是海滩还是街道，道路感知则需要知道行人在哪里、道路延伸到哪里。**图像处理** (image processing) 中的机器学习任务以图像或视频帧为对象，既包括识别这些内容，也包括生成或恢复图像。




图 1.2 同一句文本的三种输出要求。意图识别输出整句类别，信息抽取识别原文中的实体并给出类型，答案生成产生新的文本。答案句仅为输出形式示意，不声称输入已提供配送承诺。

图像分类（image classification）为整幅图像给出一个或多个类别。例如，相册管理系统可以判断照片属于海滩、街道还是室内场景，产品质检系统可以判断表面是否存在缺陷。它回答“这幅图像属于哪一类”或“图中有哪些类别的对象”，属于分类任务，通常不要求指出每个对象的具体位置。

只知道图中“有行人”，不足以判断车辆前方是否有人。**目标检测**（object detection）因此同时给出对象的类别和位置。例如，道路感知系统识别汽车、行人和交通标志，再用**边界框**（bounding box），即包围各个对象的矩形，标出它们的位置。类别判断属于分类，边界框的位置和大小通常通过回归预测，因此目标检测往往结合分类与回归。它还需要确定图中有多少个对象，输出可以包含多个检测结果。

矩形框不能精确表示道路或器官的轮廓。需要更细的区域信息时，可以采用**图像分割**（image segmentation），在像素层面划分图像，例如区分道路、建筑和天空，或勾画医学影像中的器官轮廓。**语义分割**（semantic segmentation）为每个像素赋予类别，可以看作相互关联的像素分类；**实例分割**（instance segmentation）还要区分同一类别的不同对象，例如分别标出每一位行人的轮廓。因此，分割不仅关心对象的大致位置，还关心对象占据的具体区域。

图 1.3 用同一幅街景比较目标检测与语义分割的输出。目标检测用边界框指出车辆、行人和交通标志等对象的位置，同时给出对象类别；语义分割则把道路、建筑、植被和天空等区域落实到像素层面。两者都能描述图像中的对象，但输出的空间粒度不同。




图 1.3 同一构造街景的三种表示。三幅图共用对象与位置；中间用带类别的边界框定位车辆、行人和标志，右侧用不同颜色标识语义区域，细轮廓只辅助辨认对象。图为教学示意，不是照片、真实标注或检测、分割算法的实测输出。

分析人的动作时，除了人体所占区域，还需要知道手臂、腿等部位怎样排列。**姿态估计**（pose estimation）为此预测对象的关键位置或空间姿态。以人体为例，肩、肘、膝等有明确含义的位置称为**关键点**（keypoint）；找到这些关节，就能描述身体各部分的排列，用于运动分析和人机交互。直接预测关节坐标时，可以将其建模为回归；也可以先预测关键点在各位置出现的可能性，再确定位置。输出中的各个关键点需要满足身体结构关系，因此它也是一种结构化预测。

还有一些任务需要输出一幅图像。根据文字描述绘制插图，属于**图像生成**（image generation），即产生符合要求的新图像。若手头已有受损或不完整的观测，希望据此恢复图像，则属于**图像重建**（image reconstruction），典型问题包括去除噪声、补全缺失区域，以及从低分辨率图像恢复高分辨率图像。重建可以建模为预测像素值的回归，也可以建模为受观测约束的条件生成。由于观测可能丢失信息，符合条件的结果未必唯一，恢复出的细节也未必与原始场景完全一致。

推荐与搜索 打开电影应用时，即使没有输入片名，首页也可能展示一组你感兴趣的电影。这种根据用户的兴趣、当前情境或正在浏览的内容，挑选可能对其有用的物品并呈现出来的过程，称为**推荐**（recommendation）。这里的“物品”可以是电影、商品、新闻或其他内容。例如，系统可以利用用户过去看过的电影、评分和当前浏览记录，给出一份待观看的电影列表。它要解决的是：面对大量选择，哪些内容值得主动呈现给当前用户？

如果用户已经想看某类电影，可以输入“适合孩子看的太空电影”，让系统寻找符合要求的结果。**搜索**（search）根据用户提交的查询，从内容集合中找出满足当前信息需求的对象。查询是用户对需求的表达，可以是关键词、一句话，也可以是一张图片。以文字搜电影时，输入包括查询和

可供检索的电影信息，输出是与查询相关的电影列表。这类根据需求查找内容的问题属于**信息检索**（information retrieval）¹¹。

推荐与搜索的主要区别在于需求如何表达。推荐通常从行为和情境中推测用户可能需要什么，搜索则以用户当前提交的查询为直接依据。喜欢科幻片的用户可能愿意接受一部太空惊悚片的推荐，但当他搜索“适合孩子看的太空电影”时，这部电影就未必合适。两者的共同目标是从大量内容中选出有用的结果，都需要判断内容与需求是否匹配，并安排展示次序。它们还可以共享用户信息、内容特征和交互反馈：搜索可以考虑个人偏好，推荐也可以利用近期搜索了解用户当前的兴趣。

为了完成这些应用目标，系统通常需要解决若干更具体的任务。下面沿着从理解需求、选择候选到展示结果的过程，说明哪些问题可以用机器学习处理，以及每项任务要预测什么。

在搜索中，系统需要从查询里识别用户想找的对象和条件，这属于**查询理解**（query understanding）。对于“适合孩子看的太空电影”，把查询归入“找电影”可以建模为文本分类；从中提取“太空”这一题材和“孩子”这一受众条件，可以建模为信息抽取或序列标注。模型的输入是查询文本，输出是意图类别或带有含义的文本片段，供后续检索使用。

明确需求后，逐一精细比较全部内容可能代价过高。**候选生成**（candidate generation），也常称**候选召回**（candidate retrieval），从大量物品中找出一小批可能有用的对象。推荐需要匹配用户与物品，搜索需要匹配查询与物品。使用机器学习时，可以根据历史交互或相关性标注学习匹配得分：输入用户信息与电影信息，估计兴趣是否相符；输入查询与电影简介，估计内容是否相关。系统据此筛选候选，再交给后续环节细致比较。这里最终输出的是一个候选集合，目标是在限制计算量的同时尽量保留有用的结果。

对每个候选，系统还可以预测用户的评价或行为。**评分预测**（rating prediction）根据用户与物品信息，估计用户会给出多少分；把评分当作数值时，可以按回归任务学习。**点击率预测**（click-through rate prediction）估计某个结果展示后被点击的概率，通常用历史记录中的“点击/未点击”作为二分类标签。**转化率预测**（conversion rate prediction）则估计在规定的条件下发生购买等目标行为的概率，例如用户点击商品后是否购买。推荐和搜索都可以使用这些预测，但预测目标需要明确：更可能被点击，不一定意味着更符合查询或更能让用户满意。

单个物品的预测结果还需要转成一份有次序的列表，这就是排序任务。推荐排序比较物品对当前用户的价值，搜索排序比较结果对当前查询的相关程度。**学习排序**（learning to rank）利用已有的相关性标注、用户偏好或交互反馈，学习候选之间应该怎样排列。例如，训练数据可以指出，对于“适合孩子看的太空电影”，一部儿童科幻片应排在一部太空惊悚片之

¹¹ C. D. Manning, P. Raghavan, H. Schütze, *Introduction to Information Retrieval*, Cambridge University Press, 2008

前。模型的输入是当前需求与候选信息，输出是用于排列候选的得分或相对次序；评价时关注有用结果是否排在前面。列表还可以经过**重排序**（reranking）进一步调整，例如减少近乎重复的推荐，或兼顾相关性与内容的多样性。重排序可以使用学习模型，也可以采用明确的规则¹²。

用户的需求会随交互改变，因此系统有时还需要预测接下来会发生什么。**序列推荐**（sequential recommendation）根据按时间排列的历史行为，预测用户接下来可能感兴趣的物品。例如，用户连续浏览了几部儿童动画后，当前兴趣可能与长期偏爱的科幻题材不同。若目标是预测下一次选择，可以建模为分类或排序；若目标还包括当前展示如何影响后续观看和长期体验，就需要比较一系列行动的后果，形成**序贯决策**（sequential decision making）问题。

这些任务可以在同一个系统中组合：查询理解提供需求信息，候选匹配缩小范围，评分或行为预测为排序提供依据，排序决定展示结果。并非每个环节都必须使用学习模型，例如搜索的候选检索也可以依靠关键词匹配。使用交互记录学习时，还要考虑反馈是怎样产生的：排在前面的结果更容易被看到和点击，点击次数因此不能直接当作相关性，需要考虑展示位置的影响¹³。

其他领域 除了自然语言处理、图像处理、推荐与搜索，机器学习还广泛用于科学研究、工业生产，以及各种需要根据复杂观测进行预测或决策的系统。不同领域面对的数据形式和现实约束各不相同，但其中的问题往往仍可归纳为分类、回归、聚类、生成或序贯决策等任务。下面以生命科学、自动化与控制系统和语音处理为例作简要说明。

在生命科学（life sciences）中，机器学习可以处理细胞测量、基因表达（gene expression）和分子结构等数据。例如，**细胞类型识别**（cell type identification）根据细胞的测量特征判断其类型，可以建模为分类；将具有相似基因表达模式的细胞归组，可以采用聚类；**分子性质预测**（molecular property prediction）根据分子结构估计溶解度等数值性质，可以建模为回归；**分子生成**（molecular generation）则根据期望性质提出候选分子结构，属于生成任务。这些预测和候选还需要结合领域知识及实验进行验证。

在自动化与控制系统（automation and control systems）中，**故障诊断**（fault diagnosis）根据传感器记录识别设备的故障类型，可以建模为分类；**系统辨识**（system identification）从观测数据中学习系统的动态关系，例如根据当前温度和加热功率预测后续温度，其中的数值预测可以采用回归。机器人控制需要根据环境和自身状态连续选择行动，属于序贯决策；它可以结合感知、状态预测和行动选择等多个任务。

在**语音处理**（speech processing）中，**语音识别**（speech recognition）将音频转换为文字，需要根据连续的声学信号预测文字序列；**语音合成**（speech

¹² Google, *Recommendation Systems Overview*, Aug. 25, 2025, URL: <https://developers.google.com/machine-learning/recommendation/overview/types>

¹³ T. Joachims, A. Swaminathan, T. Schnabel, *Unbiased Learning-to-Rank with Biased Feedback*, 2016, arXiv: 1608.04468, URL: <https://arxiv.org/abs/1608.04468>

任务	典型输出	主要目标	例子
分类	一个或多个离散类别	判断输入属于哪些类别	垃圾邮件识别、图像分类
回归	连续数值	使预测值接近目标数值	评分预测、需求预测
排序	相关性分数或候选次序	把更相关或更有用的对象排在前面	文档检索、推荐排序
聚类	样本的组别或结构	使同组样本更相似、异组样本更不同	文档主题探索、用户分群
降维	低维表示	用较少变量保留数据的主要结构	数据可视化、压缩
生成	文本、图像、音频等新对象	产生符合条件或数据规律的内容	摘要、翻译、图像生成
序贯决策	随状态变化的一系列行动	提高一段时间内的累计回报	机器人控制、交互式推荐

表 1.7 常见机器学习任务的输出、目标和应用例子。任务按问题形式抽象，不等同于应用领域或学习范式。

synthesis) 则根据文本产生语音。前者涉及**序列预测** (sequence prediction), 后者属于条件生成。

这些应用说明，**应用场景** (application scenario) 描述问题在什么环境中被使用，任务则明确系统需要完成的具体工作。

1.3.2 常见任务类型

现在可以暂时放下应用领域，比较这些问题的共同形式。情感分析、图像分类和故障诊断都要输出类别；分子性质预测与评分预测都要输出数值。**分类** (classification) 和回归等名称抓住了这些共性，使不同领域的问题可以共享建模方法。表 1.7按输出和目标整理常见任务，下面进一步说明它们的区别与联系。

分类从给定的离散类别中作出判断。邮件案例中的二分类只有两个候选类别；**多分类** (multiclass classification) 从多个互斥类别中选择一个，例如正面、负面和中性情感；**多标签分类** (multilabel classification) 允许一个样本同时属于多个类别，例如一张照片同时具有“海滩”“日落”和“人物”等标签。为句子中的每个位置或图像中的每个像素分类，还需要考虑输出之间的关联，而不能只把它们看作互不相干的判断。

回归输出连续数值，例如房屋价格、用电量或观看时长。分类模型也常先输出一个连续分数或概率，再通过阈值得到离散类别；此时最终任务仍是分类，因为系统要作出的决定和采用的评价指标针对类别。反过来，也可以把连续目标划分为若干区间后改成分类，但这种处理会丢失区间内部的数值差异。任务名称应由最终输出和使用目标决定，不能只看模型内部产生的是分数还是类别。

排序关心候选对象的相对次序。搜索和推荐通常更在意相关文档或物品能否排在前面，而不要求每个候选的分数具有精确的数值含义。

为了得到这样的次序，可以在不同范围内比较候选。**逐点方法** (pointwise approach) 把每个候选是否相关看成分类，或者把相关程度看成回归，再按预测分数排序；**成对方法** (pairwise approach) 比较两个候选的优先次

序，可以把“哪一个更相关”建模为二分类；**列表方法**（listwise approach）则根据整个候选列表的排序效果组织学习。任务之间的转化让排序问题可以使用分类或回归方法，但最终仍应使用面向次序的指标评价结果。

聚类（clustering）根据某种相似性把样本组织成组，常用于探索文档主题或用户群体。聚类没有预先指定的唯一类别答案，结果是否有意义取决于表示方式、相似性定义和使用目的。它与分类的区别在于，需要从数据中探索组别，而不是为样本选择一个预先规定的类别。

降维（dimensionality reduction）用较少变量保留数据中的主要结构，可以用于可视化、压缩，也可以为分类、回归或聚类提供新的特征表示。聚类与降维经常配合使用，但一个产生组别，另一个产生低维表示，二者解决的问题并不相同。

生成（generation）产生文本、图像、语音或其他结构化对象。翻译、摘要和图像生成都要构造包含多个部分的输出，而不是只选择一个类别或预测一个数值。生成模型在每一步可能仍会计算词语或像素的概率，但整个任务关注的是完整输出是否符合输入条件和数据规律。

序贯决策输出随状态变化的一系列行动。它与独立地预测一个样本不同：当前行动会改变接下来能够观察到的状态，也会影响未来可以获得的回报。机器人控制、广告投放和交互式推荐都可能属于这类任务。系统内部仍可用分类模型选择动作，或用回归模型估计未来回报，但整体目标是提高一段时间内的累计收益。

任务类型描述问题的输出和目标，而不唯一规定实现方式。一个问题可以被分解为多项任务，也可以转换成其他形式来求解：目标检测组合分类与位置回归，推荐排序可以借助点击概率预测，降维得到的表示可以作为聚类或分类的输入。建模时需要检查这种分解或转换是否保留了原问题关心的信息，并用符合实际目标的标准评价最终结果。

1.3.3 任务与学习范式

即使任务已经明确，学习过程也未必相同。仍以文本分类为例：我们可以直接使用带标签的文本，也可以先利用大量无标签文本学习表示，再用少量标签训练分类器。区别在于使用了什么经验、从哪里获得反馈，以及如何组织训练。这些选择由**学习范式**（learning paradigm）描述。任务说明要完成什么，范式说明怎样从经验中学习，两者需要分别交代。

同一个分类任务可以直接利用完整标签，也可以结合少量标签与无标签数据，或者先从数据自身构造训练目标再学习表示。序贯决策还可能从动作示范或行动后果中获得反馈；经验持续到来时，又要决定怎样更新模型并保留已有能力。这些差别不会自动改变任务本身，却会改变学习过程能够使用的信息和需要满足的条件。

因此，应用场景、任务和范式分别回答“在哪里使用”“要完成什么”和“怎样从经验中学习”。同一场景可以组合多种任务，同一任务可以采用不同范式，同一范式也能够服务多种任务。后续第3章将正式定义并比较这些学习范式。

1.4 经验

模型从已经观察到的样本、反馈或交互中学习，这些可供学习使用的信息构成经验。数据是经验在计算系统中的具体载体。在垃圾邮件案例中，一封邮件是原始对象， $(\mathbf{x}_i, y_i)$ 是一个带标签样本， $\mathbf{x}_i$ 是模型输入的特征表示， y_i 是希望预测的标签。对图像，原始像素可以直接成为输入，也可以先转换为其他表示；对语音和传感器记录，一个样本可能是有时间顺序的序列；在推荐场景中，样本还可能由用户、物品、时间和交互共同构成。

特征既可以由人设计，也可以从数据中学习。前者如邮件中的词数和链接数，含义直观，却可能丢失上下文；后者如神经网络的中间表示，能够适应复杂数据，但通常更难直接解释。标签只是学习信号的一种形式。无标签样本、成对偏好、交互轨迹和奖励都可能构成经验，它们支持的学习范式和训练目标并不相同。

手中的邮件只占未来可能收到的邮件的一小部分。要用它们判断未来表现，需要说明两者通过什么规律联系起来。**数据分布** (data distribution) 描述哪些输入和标签组合出现得更频繁，并为各种情形赋予概率；数据集则是按照某种采样方式得到的有限记录。

理论分析经常采用**独立同分布** (independent and identically distributed, i.i.d.) 假设。“独立”要求样本之间没有统计依赖，“同分布”要求每个样本都来自同一概率规律。在这两项条件成立时，许多经典统计学习工具可以直接分析样本与总体之间的关系。条件不成立并不表示数据无法分析，但必须显式描述依赖结构、群组差异或分布变化，并改用与之匹配的统计工具。实际数据因而需要另行检查：相邻时间的传感器读数常常相关，不同用户的数据分布可能不同，垃圾邮件的写法也会随时间改变。

即使没有足够信息精确写出数据分布，也应检查数据是否覆盖模型实际面对的情形。来源过于集中时，即使样本很多，也可能遗漏特定用户、设备或场景；测量误差与标注分歧会降低样本的可靠性，类别不平衡则可能让数量较少但更重要的事件被多数样本掩盖。因此，与其单纯增加来自同一狭窄来源的数据，不如优先补充目标场景中缺失的情形，并检查测量和标签质量。

在这样的数据条件下，还要决定哪些信息可以用于学习，哪些应留作检验。邮件案例中的三种数据子集因此有不同职责：

- 训练集用于学习模型参数，也用于拟合词表、归一化系数等预处理规

则；

- 验证集用于选择超参数、比较候选模型和决定何时停止训练；
- 测试集在所有选择完成后估计最终系统对未见数据的表现。

图 1.4 用按时间预测未来邮件的情形说明这种分工。随机划分适合许多近似同分布的场景，却不是默认正确答案。预测未来时应考虑按时间划分；希望推广到新用户时，同一用户的数据不应同时出现在训练和测试两侧。




图 1.4 训练集、验证集和测试集的用途。时间箭头表示一种面向未来预测的划分方式；记录数量仅作示意，不代表划分比例。训练集用于参数学习与预处理拟合，验证集用于配置和停止位置的选择，测试集在这些选择冻结后才用于最终评估。

如果学习或选择过程提前利用了本不应获得的信息，就会发生**信息泄漏**（information leakage）。例如，同一封邮件的副本同时进入训练集和测试集，模型可能靠记住内容通过测试；先用全体数据选词，再划出测试集，也已经利用了测试数据。反复查看测试成绩并据此改模型同样破坏了它的独立性。这样的评价往往过于乐观，因为部署时无法提前利用待预测样本的答案或整批未来数据。

数据划分并不能解决所有问题。一个干净的测试集只能回答“模型在这个测试分布上表现如何”。如果目标用户、采集设备或时间范围改变，还需要新的验证与监测。数据的来源、生成过程和使用条件，和数据矩阵本身同样重要。

1.5 性能度量

性能度量把应用目标变成可比较的数量。选择指标之前，应先说明哪类结果重要、错误代价是否对称以及与什么基线比较。垃圾邮件系统中，漏放一封广告邮件会打扰用户，误拦一封重要邮件则可能造成更大损失，因此只报告总体准确率不足以支持部署决策。

要区分两类错误，可以把每封邮件的真实标签和预测标签交叉对照，形成**混淆矩阵**（confusion matrix）：表的四个格子分别记录两种正确判断和两种错误。在本例中，真正例（true positive, TP）是正确识别的垃圾邮件，假正例（false positive, FP）是被误拦的正常邮件，假负例（false negative, FN）是漏放的垃圾邮件，真负例（true negative, TN）是正确放行的正常邮件。表 1.8由表 1.5逐行汇总而来。

		预测类别	
		垃圾邮件	正常邮件
真实类别	垃圾邮件	TP = 3	FN = 0
	正常邮件	FP = 2	TN = 3

表 1.8 垃圾邮件测试结果的混淆矩阵。行表示真实类别，列表示预测类别；“垃圾邮件”被约定为正类。

我们可以从这张表提出三个不同问题：全部邮件中有多少判对了？拦下的邮件中有多少确实是垃圾邮件？真正的垃圾邮件又找回了多少？它们分别对应**准确率**（accuracy）、**精确率**（precision）和**召回率**（recall）。 F_1 值（F1 score）用精确率和召回率的调和平均数综合二者，只有二者都较高时才会较高。计算公式为

$$\text{准确率} = \frac{TP + TN}{TP + FP + FN + TN}, \quad (1.10)$$

$$\text{精确率} = \frac{TP}{TP + FP}, \quad (1.11)$$

$$\text{召回率} = \frac{TP}{TP + FN}, \quad (1.12)$$

$$F_1 = \frac{2 \times \text{精确率} \times \text{召回率}}{\text{精确率} + \text{召回率}}. \quad (1.13)$$

在本例中，准确率为 $6/8 = 0.75$ ，精确率为 $3/5 = 0.60$ ，召回率为 $3/3 = 1.00$ ， $F_1 = 0.75$ 。召回率为 1 说明测试集里的垃圾邮件都被识别出来；精确率只有 0.60 说明被拦截的 5 封邮件中有 2 封其实是正常邮件。使用这些公式时还需检查分母：如果没有邮件被预测为正类，精确率就不能直接按此计算；如果测试集中没有正类，召回率也同样如此。报告结果时应说明这类情况的处理约定。

类别极不平衡时，准确率尤其容易掩盖问题。若一万封邮件中只有十封垃圾邮件，全部判为正常也能得到 99.9% 准确率，却没有完成识别垃圾邮件的目标。精确率和召回率能从不同角度揭示这一点，但 F_1 也没有直接表达误拦与漏放的实际代价，不能自动替代应用中的取舍。提高分类阈值后，被拦截的邮件会减少或保持不变，召回率不会上升；精确率是否提高则取决于被排除的是正常邮件还是垃圾邮件。阈值应在验证集上根据应用代价选择，不能看过测试结果再调节。

如果预测的是数值，就可以直接检查预测值偏离真实值多远。**平均绝**

对误差（mean absolute error, MAE）对偏差的绝对值取平均，**均方误差**（mean squared error, MSE）则对偏差的平方取平均。对 n 个评估样本，记真实值为 y_i 、预测值为 $\hat{y}_i$ ，则

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |\hat{y}_i - y_i|, \quad (1.14)$$

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (\hat{y}_i - y_i)^2. \quad (1.15)$$

平方会使大误差受到更重惩罚，因此两者表达不同偏好。排序、生成和序贯决策也各有相应指标，评价时还可能需要结合人工判断、延迟、资源消耗和长期影响。本章不逐一罗列，而强调指标必须与任务和使用条件相匹配。

这些指标都是在有限样本上计算的，真正关心的却是未来数据上的表现。式 (1.3) 给出一次预测的损失，式 (1.4) 把它在训练集上取平均，得到经验风险。若改为按未来数据的概率规律取平均，就得到**期望风险**（expected risk，也称 population risk），即模型在目标分布上的平均损失。记随机输入及其标签为 $(\mathbf{X}, Y)$ ，目标分布为 $\mathcal{P}$ ，则

$$R(\theta) = \mathbb{E}_{(\mathbf{X}, Y) \sim \mathcal{P}} [\ell(f_{\theta}(\mathbf{X}), Y)]. \quad (1.16)$$

式中的 $\mathbb{E}$ 表示取期望，也就是按各种情形出现的概率对损失加权平均。目标分布通常未知，因此用独立测试集估计平均损失或任务指标。这个估计只适用于相应的采样条件，不能保证任意未来环境中的表现。比较模型时，应使用相同的数据划分、可用信息和评价口径。预处理方案与阈值可用验证集选择，词表、均值等参数仍只用训练集拟合。报告时应交代选择方式与估计的不确定性。

1.6 本章小结

计算机可以用特征保留输入中的可用信息，以模型假设限定候选规律，再利用历史数据选择具体模型，从而形成处理新输入的规则。检验这种能力，需要在模型和配置固定后，使用未参与学习的数据并按任务指标评价结果。垃圾邮件案例走完了这条路径，也说明训练成绩不能单独保证规则适用于未见邮件。本章把泛化变成了可检验的问题，并未证明它在什么条件下必然可靠。

描述一个学习问题，因而既要说清任务、经验和性能度量，也要交代数据与未来场景的关系。本例的模型比简单基线识别出更多垃圾邮件，同时误拦了正常邮件，这说明“学得更好”必须结合实际目标判断。数据是否有代表性、信息是否泄漏、指标是否反映错误代价，都会改变我们对学习结果的解释。

延伸阅读 若想追溯“经验为何能够支持新判断”这一问题，可继续阅读 D. Hume 对经验与归纳的讨论，以及 J. De Houwer 等人关于学习定义的综述。若想了解机器学习三要素和早期发展，可分别参见 T. M. Mitchell 的教材、A. M. Turing 关于学习机器的讨论以及 A. L. Samuel 的跳棋研究。后续第 2 章将建立比较模型的几个基本维度，第 3 章系统介绍经验与反馈怎样组织成不同的学习范式，第 2 部分则进一步追问有限数据在什么条件下能够支持泛化。

模型简介

有了带标签的历史邮件，我们仍有几种不同的办法判断新邮件：学习一组特征权重，建立一棵判断规则树，或者保存历史邮件，在预测时寻找相似样本。第1章的邮件案例展示了根据标签调整权重的过程，但同样的标签也能用于学习其他形式的规律。怎样表示这些规律，是选择模型时需要回答的问题。

比较这些模型，不能只看它们最终返回的标签。表示规模说明模型需要保存多少信息，概率语义与关系形式说明模型怎样描述变量及其联系。输出接口说明使用者会得到什么，损失与学习准则则决定训练时怎样评价候选模型。本章从邮件例子出发，先区分候选模型、具体模型与训练过程，再用这五个维度比较分类与聚类模型，找出不同方法共享的假设和各自作出的选择。

2.1 什么是模型

继续使用第1章的邮件例子。每封邮件由促销提示词次数与外部链接数表示，记为 $\mathbf{x} = (x_1, x_2)^T$ 。规定“对这两个特征加权求和，再转成垃圾邮件的概率”，只是选定了一种预测形式。只要权重还没有确定，同一封邮件就可能得到不同的概率。这里需要区分两个对象：训练前允许选择的整组候选关系，以及训练后实际使用的某一个关系。满足给定形式与约束的一组候选模型称为**模型族** (model family)，记为 $\mathcal{H}$ ；其中一个具体模型记为 $h \in \mathcal{H}$ 。预测任务中的模型族通常也称为假设空间；“模型族”则还适用于聚类、降维和分布建模等不只输出预测标签的任务。

模型族给出选择范围，具体模型给出计算依据。邮件分类需要确定的量是各特征的权重；换成其他任务，也可能要确定代表群组的中心位置，或压缩数据时使用的投影方向。

在给定表示方式下，需要从数据中估计、用于确定具体模型的量是模型参数。回归系数、聚类中心的坐标和神经网络权重都属于这类参数。用 θ 统称这些量时， h_θ 表示由这组参数确定的模型。

沿用前文的邮件预测式，用 $\theta = (b, w_1, w_2)^\top$ 记录参数，可以把具体模型与模型族写在一起：

$$h_\theta(x) = \frac{1}{1 + \exp[-(b + w_1x_1 + w_2x_2)]}, \quad (2.1)$$

$$\mathcal{H} = \{h_\theta : \theta \in \mathbb{R}^3\}.$$

其中， w_1, w_2 是两个特征的权重， b 是在加权和之外加入的偏置。集合 $\mathcal{H}$ 包含所有允许的权重组合所确定的模型；例如，令 $b = -2$ 、 $w_1 = 0.8$ 、 $w_2 = 0.3$ ，就选出了其中一个具体模型。这里的数值仅用于说明概念。换一组权重，通常会得到同一模型族中的另一个模型；把加权和换成条件分支树，则改变了所考虑的模型族。

确定候选范围以后，还要有一种办法根据数据作出选择，这才是学习算法的工作。在邮件例子中，算法根据训练样本调整三个参数。换一种优化算法，调整参数的步骤可能不同，允许选择的预测关系却可以保持不变。模型族、模型参数和学习算法分别说明“可以选什么”“选中了什么”和“怎样选”。

除了要估计的模型参数，还常需指定超参数，例如网络的层数、聚类的簇数、近邻方法的邻居数。超参数规定候选范围或学习规则，也可以借助验证数据选择。例如，先确定网络有几层，才能确定需要学习哪些连接权重；先确定每次参考几个近邻，才能执行相应的投票规则。一个方法的超参数很少，预测时仍可能需要保存大量信息，下一节的近邻方法就属于这种情形。

邮件也可以提出分类之外的问题。若想把相似邮件放在一起，可以用若干代表点描述群组；若想压缩特征，可以学习一个低维子空间；若想描述邮件特征怎样共同出现，可以建立它们的概率分布。模型因任务而改变，输出可能是一个标签、一组坐标或一个分布，但都需要说明保存了什么规律、怎样使用这些规律，以及怎样从数据中得到它们。

表2.1列出本章采用的五个观察维度。这是一种组织和比较模型的方法，并非把所有模型放进一棵互不重叠的分类树。参数化方式与表示规模、概率语义和关系形式分别考察表示规模、分布假设与变量关系；输出接口考察模型在使用时返回什么；损失与学习准则则考察学习时用什么准则评价候选模型。

式(2.1)给出的逻辑回归就同时涉及这五个问题：它保存三个参数，通过加权和计算类别概率，并根据概率与已知标签的吻合程度学习参数。如果只看最终返回的“垃圾邮件”标签，这些差别就被隐藏了。下面从模型需要保存多少信息入手，逐步展开这些问题，并用预测、聚类与压缩中的例子作比较。

维度	要回答的问题	主要观察方向
参数化方式与表示规模	模型表示规模是否有固定上限？	参数化、非参数化及半参数化组合
概率语义	是否为有关变量明确建立概率分布？	非概率、概率
关系形式	有关变量怎样发生联系？	线性、非线性
输出接口	使用模型时返回什么？	组织形式与结果含义
损失与学习准则	怎样评价候选模型？	逐样本差异、关系与结构、轨迹与长期目标

表 2.1 认识模型的五個维度。每个维度回答不同问题，不能由其中一项直接推断其余各项。

2.2 参数化方式与表示规模

训练邮件从一百封增加到一万封后，模型要保存的信息会怎样变化？有的方法仍只更新原来的几个权重，有的方法则保留更多样本或增加更多判断分支。这种差别是理解**容量**（capacity）的一个起点：容量关心一个模型族能够表达多丰富的关系。

本节考察表示规模是否受预先固定的参数维数限制，并介绍两类表示的组合。这里观察的是整个候选范围：一次训练得到的模型即使能用有限信息保存，也不能据此断定所有候选模型的表示规模都有固定上限。参数范围和结构限制同样会影响容量；它们与泛化的理论联系留到第2部分。

2.2.1 参数化模型

固定输入表示与模型配置后，如果模型族中的候选模型由预先固定维数的参数向量描述，就称为**参数化模型族**（parametric model family），通常简称参数化模型。例如，将允许的参数向量限制在 $\mathbb{R}^p$ 中的某个范围内， p 便是参数维数。这里的关键是 p 不会仅因训练样本数 n 增加而自动增长，而参数的具体取值仍要从数据中估计。

以 d 维输入的线性回归为例，每个模型由 d 个权重与一个偏置确定，所以 $p = d + 1$ 。当训练数据从一百个样本增加到一万个时，需要重新估计的数值可能改变，但仍是这 $d + 1$ 个数值。训练以后，只用这些权重与偏置就能对新输入作预测。固定层数、宽度与连接方式的神经网络也有这样的性质；其参数可以很多，但数量由配置确定，不随样本数量自动增加。

参数化模型并不限于预测任务。用于聚类的**k 均值模型**（K-means）用 k 个中心代表数据中的群组，把新样本分给最近的中心。这类代表点也称为原型。固定输入维数 d 和簇数 k 后，模型参数是 k 个中心的坐标，共 kd 个数值。例如，二维数据分成两簇时，只需保存两个二维中心，即四个数值，再配合最近中心规则完成分配。增加训练样本可以改变中心位置，但无需为每个新输入增添一组全局模型参数。

在表示学习中，**主成分分析**（principal component analysis, PCA）用少量方向表示数据的主要变化。固定原始维数与保留方向数以后，均值和投影方向也可以用固定规模的数值表示。这里的簇数、保留方向数以及网络宽度是模型的超参数。在确定一个模型是参数化还是非参数化时，要先固定这些配置，再观察模型族的表示规模如何随数据变化。

2.2.2 非参数化模型

如果希望在数据增加时保留更细的局部关系，就可以允许表示规模一同增长。这类方法所用的**非参数化模型族**（nonparametric model family），不把候选关系限制在预先固定的有限维参数形式中。“非参数化”描述的是这个限制被放宽了，模型仍然有待确定的数值，算法也仍有需要选择的设置。

k 近邻（ k -nearest neighbors, k NN）分类器采用了一种直接的做法：保存训练样本及其标签，预测新邮件时找出特征最接近的 k 封历史邮件，再按标签投票。这里的 k 控制每次查询所用的邻居数量，属于上一节所说的超参数。

只知道 $k = 3$ ，还无法对一封新邮件分类：必须知道保存了哪些样本、它们位于什么位置，以及它们的标签。同样设置 $k = 3$ ，两份不同的训练数据可以给出不同的预测规则。标准 k NN 在一百个样本上保存一百组特征和标签，在一万个样本上则保存一万组；每次查询仍只取三个邻居，但具体是哪三个，要由新输入与全部已保存样本之间的关系决定。

预测仍依赖全部已保存实例，而不只是数字 3。随着训练样本增加，不同位置附近可用于预测的信息增多，模型能够形成更细的局部划分。这种表示方式不受固定维数的系数向量限制，是 k NN 被归为非参数化方法的原因。即使用验证集选择 k ， k 控制邻域范围、实例提供预测依据的分工也没有改变。

这与 K-means 中的 k 作用不同。固定 K-means 的簇数，就固定了需要学习的中心数量；固定 k NN 的邻居数，只固定一次查询的参与者数量，并未固定需要保留的实例数量。图2.1用这两种方法对照超参数与模型表示之间的关系。

非参数化也不意味着无需假设。 k NN 依赖所选距离、特征尺度和邻居数：距离决定哪些样本接近， k 决定一次投票参考多大的局部范围。保存更多实例会增加存储与查询成本，改变特征尺度也可能改变邻居关系。这里保存实例是为了完成预测。线性回归的程序也可能为重新训练、检查误差或记录来源而保存全部数据，但其预测关系仍能由固定数量的权重表示。区分两类模型，需要看预测关系怎样表示；程序中恰好保留了多少文件或样本，本身不足以作判断。




图 2.1 两个 k 控制不同的对象。左侧 kNN 保存十个带标签样本，菱形表示新输入，虚线圈内的三个近邻参加投票；右侧 K-means 用两个中心表示群组。固定近邻数不会固定实例总数，固定簇数则固定了中心数量。图为表示方式的教学示意。

局部关系也可以通过增加规则来细化。**决策树** (decision tree) 根据特征阈值逐步分支，把输入分到不同区域，再给出各区域的预测。如果不预先固定叶节点数的上限，更多样本可以支持更多分支，所需阈值和叶节点输出的数量也可以增加，因此属于非参数化设定。若将树深度或叶节点数固定在某个上限内，则变成了表示规模有固定上限的设定。树的区域划分将在第2.4.2节说明。

随机森林 (random forest) 综合多棵决策树的预测。即使树的棵数固定，只要各树的叶节点数量仍可随数据增长，整体也可以采用非参数化设定。若棵数与每棵树的叶节点上限都固定，表示规模才相应受到固定限制。这与 kNN 类似：固定一个超参数，不一定固定模型的全部自由度。

核回归 (kernel regression) 按输入之间的距离或相似性，对训练样本的目标值作局部加权平均。控制邻近范围的尺度通常称为带宽，它是超参数；预测所依据的样本位置和目标值仍可随数据增加。例如，带宽不变时，增加附近的房屋成交记录仍会改变当前位置的加权房价预测。这种由实例不断补充局部关系的方式，也属于非参数化方法。近邻、树与局部平滑方法的联系可在统计学习教材中进一步比较¹。

2.2.3 半参数化模型

用面积与楼龄预测房价时，我们可能愿意假设面积的作用是线性的，却不确定楼龄与房价之间适合用什么曲线。此时可以保留明确的面积项，让楼龄项从数据中更灵活地学习。**半参数化模型** (semiparametric model) 就把固定有限维的参数化部分与非参数化部分结合起来。记面积为 x 、楼龄为 z ，一个教学设定是

$$f_{\beta, g}(x, z) = \beta x + g(z). \quad (2.2)$$

系数 β 描述面积的固定线性作用，未知函数 g 描述楼龄与房价之间的关系，后者可以用局部平滑等非参数化方法估计。学习时既要确定 β ，也要

¹ T. Hastie, R. Tibshirani, J. Friedman, *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*, Springer, 2009, 2nd ed.

估计整条函数 g 。“半参数化”指这两部分的结合，并不是参数数量介于某两个模型之间，也不是一半参数已知。

同一种方法也可能采用不同的容量设定。以**支持向量机** (support vector machine, SVM) 为例，它根据得分判断类别，学习时要求样本尽量位于边界的正确一侧，并与边界保持一定距离。这里考察其表示规模；相关几何要求将在第2.6.2节介绍。

固定 d 维输入的线性 SVM 使用 $s(\mathbf{x}) = \mathbf{w}^\top \mathbf{x} + b$ ，全部预测关系由 d 个权重与一个偏置确定，所以属于参数化设定。采用核函数时，得分则常写成训练样本贡献的加权和：

$$s(\mathbf{x}) = \sum_{i \in I_{SV}} a_i \kappa(\mathbf{x}_i, \mathbf{x}) + b. \quad (2.3)$$

其中 κ 是用于计算两个输入之间关系的核函数， a_i 为学习得到的系数， $I_{SV} \subseteq \{1, \dots, n\}$ 包含非零系数对应的训练样本索引，这些样本称为**支持向量** (support vectors)。核函数与特征变换的关系见第2.4.2节。

对于通常的高斯核 SVM，支持向量的数量可以随样本量增加，模型也没有等价的固定有限维特征表示，因此通常归为非参数化模型。只保留一部分训练样本，可以使具体模型更紧凑，但不意味着整个模型族变成半参数化；固定核的带宽或其他训练超参数，也不会固定支持向量数。如果核对应固定的有限维特征，例如固定次数的多项式核，则又可以用固定维数的权重表示，需要按这一具体设定判断。

要得到半参数化 SVM，需要在预测关系中明确结合两种部分。例如，让得分或回归预测包含一个可解释的线性趋势，再加上由非参数化核函数模型学习的修正项；前者具有固定数量的系数，后者可以随数据扩展。已有研究将支持向量方法扩展到这种组合形式，并联合学习两部分²。SVM 的容量取决于这些具体设定：线性形式具有固定维数的表示；核形式要看核对应的特征空间；半参数化形式则明确组合了两类部分。超参数只有几个，或某次训练得到的支持向量只有有限个，都不能替代对整个候选范围的判断。

² A. J. Smola, T.-T. Frieß, B. Schölkopf, *Semiparametric Support Vector and Linear Programming Machines* In *Advances in Neural Information Processing Systems* 11, 1998

2.3 变量的概率语义

即使确定了模型的表示规模，预测时仍有一个选择：只给出结果，还是同时说明结果可能怎样变化？假设根据今天的气象观测预测明天的温度，模型可以直接给出 22 °C，也可以描述温度落在不同范围内的可能性，例如主要集中在 20 到 24 °C 之间。后一种做法需要为可能的结果建立概率分布。这个选择同样会出现在聚类、降维与分类中。

2.3.1 非概率模型

非概率模型 (non-probabilistic model) 不为所考察的变量明确建立概率分布，而是用函数、规则或几何关系直接确定结果。在温度预测中，记气象特征为 $\mathbf{x}$ 、模型参数为 θ ，模型计算

$$\hat{y} = f_{\theta}(\mathbf{x}). \quad (2.4)$$

训练时，根据预测温度与实际温度的偏差调整参数；使用时，将新的观测代入函数，得到一个预测值。例如，输出 22°C 表示模型给出的温度预测。这个数值本身没有描述预测可能偏离多少，也没有说明较低或较高温度出现的可能程度。

K-means 和 PCA 也可以直接用几何关系定义。K-means 寻找若干中心，使样本尽量靠近各自的中心；给定新样本后，比较距离并返回最近中心的编号。PCA 寻找少量投影方向，用低维坐标保留数据的主要变化；给定新样本后，计算它沿这些方向的坐标。两者分别依赖距离与投影，不需要先规定样本服从什么概率分布。

温度误差、簇内距离和重构误差都能直接用来评价这些模型。当任务需要的是一个预测值、一个分组或一组坐标时，这样的建模已经可以完成工作。如果还要判断温度偏离预测值超过两度的概率有多大，就需要额外的概率描述。

2.3.2 概率模型

同样的气象特征未必对应完全相同的明日温度。要保留这种变化，可以把温度看成一个随机变量，用分布描述各个范围内出现的可能性。**概率模型** (probabilistic model) 就是为任务涉及的随机变量及其关系建立概率分布的模型。对于温度预测，可以让函数给出分布的均值，并用方差描述围绕均值的变化：

$$y | \mathbf{x} \sim \mathcal{N}(\mu_{\theta}(\mathbf{x}), \sigma^2). \quad (2.5)$$

这里 $y | \mathbf{x}$ 表示给定气象特征 $\mathbf{x}$ 后的温度， $\mu_{\theta}(\mathbf{x})$ 给出该条件下的均值； $\mathcal{N}(\mu, \sigma^2)$ 表示均值为 μ 、方差为 $\sigma^2 > 0$ 的高斯分布。若均值为 22°C 、标准差为 2°C ，模型既保留了一个中心预测，也描述了其他温度的可能程度。图2.2对照了这两种预测形式。

概率建模并不限于监督预测，聚类也有相应的两种做法。K-means 用中心与距离描述群组；**高斯混合模型** (Gaussian mixture model, GMM) 则用若干高斯分布描述数据，每个群组除了中心，还有各方向上的分散程度以及在总体中所占的比例。对处在两组之间的样本，K-means 按最近中心给出一个编号，GMM 可以计算它分别属于两组的概率。这样，群组的大小、形状和重叠程度都能参与分配判断。




图 2.2 同一温度预测的两种描述。左侧只给出一个预测值；右侧给出高斯预测分布，阴影面积表示温度落在 20 到 24 °C 之间的概率。数值用于教学示意。

降维也可以作同样的对照。PCA 与**概率主成分分析** (probabilistic PCA, PPCA) 都寻找低维表示，但二者对数据作出的说明不同。PCA 用线性投影压缩和重构数据；PPCA 在低维线性表示的基础上增加高斯分布与观测噪声假设，从而描述数据在这一低维空间附近怎样分布。它不仅能讨论投影位置，还能在模型假设下估计缺失观测的分布。两者联系紧密，但 PPCA 额外回答了“哪些观测更可能出现”这个问题³。

分类问题的概率建模选择 回到邮件分类，使用者关心的是：看到这些特征以后，这封邮件属于各类的概率是多少？这由类别的条件分布 $p(y | \mathbf{x})$ 回答。得到它有两条路线：直接学习特征与类别概率之间的关系，或先描述各类邮件的特征分布，再反推类别。两者分别称为判别式建模与生成式建模。

判别式建模 (discriminative modeling) 直接学习输入到类别的关系。在这里讨论的概率分类中，它直接建立 $p(y | \mathbf{x})$ 。例如，逻辑回归根据带标签样本调整权重，使给定邮件特征后的类别概率与标签相符。模型不必同时说明各种特征组合在全部邮件中出现的概率，也不必分别描述正常邮件与垃圾邮件内部的特征分布。更广义的判别式建模也可以只学习得分或决策规则，例如 SVM；本小节关注的是其中直接学习类别概率的情形。

生成式建模 (generative modeling) 用于分类时，先建立输入与类别的联合分布 $p(\mathbf{x}, y) = p(y)p(\mathbf{x} | y)$ 。其中 $p(y)$ 描述各类别的比例， $p(\mathbf{x} | y)$ 描述每一类内部的特征分布。训练得到这些分布后，再根据新输入的特征反推其类别。对于编号为 $1, \dots, k$ 的类别，由贝叶斯公式得到

$$p(y = c | \mathbf{x}) = \frac{p(y = c) p(\mathbf{x} | y = c)}{\sum_{j=1}^k p(y = j) p(\mathbf{x} | y = j)}. \quad (2.6)$$

³ M. E. Tipping, C. M. Bishop, *Probabilistic Principal Component Analysis* In Journal of the Royal Statistical Society: Series B (Statistical Methodology), 1999, vol. 61, no. 3, pp. 611–622

其中 c 是待考察类别，分母对所有类别求和，并要求其大于零。分子同时考虑类别原本有多常见，以及当前特征在该类别下有多可能出现；除以所有类别的总和，就得到观察特征后的类别概率，也称为类别后验概率。若只需输出概率最大的类别，比较各类分子即可，因为分母相同。

作为一个数值例子，约定邮件标签 1 为垃圾邮件、0 为正常邮件。假设模型得到 $p(y = 1) = 0.2$ 、 $p(y = 0) = 0.8$ ；对于某一组计数特征 $\mathbf{x}$ ， $p(\mathbf{x} | y = 1) = 0.12$ 、 $p(\mathbf{x} | y = 0) = 0.01$ 。这些数值仅用于演示计算。两类的联合概率分别为 0.024 和 0.008，因此垃圾邮件的后验概率为 $0.024 / (0.024 + 0.008) = 0.75$ 。这个结果既利用了特征的区分能力，也计入了两类邮件的总体比例。

朴素贝叶斯 (naive Bayes) 采用生成式路线，按类别估计各特征的分布。它假设给定类别后，知道一个特征的值不会进一步改变其他特征的分布，也就是特征在该条件下相互独立。这样就能用各特征的概率相乘来简化联合概率。**高斯判别分析** (Gaussian discriminant analysis) 也采用生成式路线，但用多元高斯分布描述各类特征，从而保留特征之间的相关性。“生成式”的名称来自模型所描述的数据产生过程：先按 $p(y)$ 选择类别，再按 $p(\mathbf{x} | y)$ 生成特征。在本章的邮件表示下，生成的是促销词和链接的计数；若要生成完整邮件文本，还需要对文本本身建立分布。

图2.3比较了两条路线。它们都能给出类别后验，区别在于这个后验是直接学习的，还是由所学习的联合分布推导出来的。左侧曲线把两种建模对象区分开：条件类别概率随输入改变，联合密度则同时描述特征的分布与类别的总体比例。

两条路线的差异也体现在损失与学习准则中。假设 n 个带标签样本 $(\mathbf{x}_i, y_i)$ 相互独立，来自同一分布，用 θ 分别统称各模型自己的参数。训练时可以比较不同参数给已观测数据分配了多大的概率或密度；把数据固定、把这一数值看成参数的函数，就得到**似然** (likelihood)。独立样本的似然相乘，取对数后则变成相加；再加上负号，最大化似然就变成最小化负对数似然。判别式与生成式模型采用这条准则时，分别评价条件分布与联合分布：


$$\ell_{\text{disc}}(\theta) = -\frac{1}{n} \sum_{i=1}^n \log p_{\theta}(y_i | \mathbf{x}_i), \quad (2.7)$$

$$\ell_{\text{gen}}(\theta) = -\frac{1}{n} \sum_{i=1}^n \log p_{\theta}(\mathbf{x}_i, y_i). \quad (2.8)$$

前者只评价给定输入后，模型为实际类别分配了多少概率；后者还评价输入与类别共同出现的可能程度。因此，即使两种模型最终给出的类别后验具有相同的函数形式，学习出的参数也不一定相同。

当任务只要求分类时，判别式模型可以集中学习与类别有关的关系，减

判别式



生成式




图 2.3 两分类建模路线。上排以二分类 Logistic 读出为例，令得分 $s = \ln 3$ ，则 $\sigma(s) = 1/(1 + e^{-s}) = 0.75$ ，得到类别后验 $p_1 = 0.75$ 、 $p_0 = 0.25$ 。下排沿用离散邮件教学数值，先验与类内事件概率相乘得到联合概率 0.024、0.008，再除以总和 0.032。两排数值仅作可核算示意，不假定实际训练结果相同。左侧曲线另用连续构造：先验 0.8、0.2 分别对应 $\mathcal{N}(-1, 1)$ 、 $\mathcal{N}(1, 1)$ 。上图是条件类别概率，下图是先验加权的联合密度，整个实数轴上的面积分别为 0.8 与 0.2；密度值不与右侧离散事件概率对应。

少对输入分布形状的额外假设。生成式模型描述的范围更广，还可以在相应分布假设下进行采样或补全缺失特征；代价是需要估计更多分布关系。额外假设可能帮助有限数据下的估计，也可能因与数据不符而影响分类。例如，朴素贝叶斯的条件独立假设简化了估计，但相关特征可能使其概率估计偏离实际。两条路线的表现取决于具体模型、数据与估计方法，逻辑回归和朴素贝叶斯的比较提供了一个研究实例⁴。

这两条路线都可以得到类别概率，区别在于训练时需要描述多大范围的分布关系。下面暂且认为这些分布的参数已经确定，看看如何从中计算任务需要的结果；参数本身的不确定性将在随后讨论。

从函数计算到概率推断 无论类别后验是直接建立的，还是由联合分布导出的，使用概率模型时都需要从已建立的分布计算当前任务关心的量。这个过程称为**概率推断**（probabilistic inference）。例如，在温度预测中，要

⁴ A. Y. Ng, M. I. Jordan, *On Discriminative vs. Generative Classifiers: A Comparison of Logistic Regression and Naive Bayes* In *Advances in Neural Information Processing Systems* 14, 2001, pp. 841–848

求温度落在某个区间的概率，需要将该区间内的概率密度积分：

$$\mathbb{P}(20 \leq y \leq 24 | \mathbf{x}) = \int_{20}^{24} p(y | \mathbf{x}) dy. \quad (2.9)$$

这里温度以摄氏度计。在聚类中，GMM 先描述各组内的数据分布，再根据已经观察到的样本计算其组别概率。这两种计算都从已有的概率关系出发，得到当前问题需要的分布或概率值。

温度的点预测只需代入函数求值，区间概率却需要把区间内的可能结果累积起来。更一般地，概率推断可能需要组合事件的概率，对尚未观测的变量求和或积分，以及根据新观测计算条件分布。函数仍然可以计算均值等参数，任务所要求的概率则由相应分布进一步得到。

当许多变量相互依赖时，概率推断的计算量可能迅速增加。例如，若必须逐一考虑 m 个二值变量的取值组合，就有 2^m 种情况；连续变量则可能涉及高维积分。训练还可能反复进行这些计算，才能评价模型或更新参数。因此，复杂概率模型的训练与推断常需借助采样或较简单的分布进行近似。简单分布则可能直接计算，例如上述高斯预测只需均值与方差，就能确定整条密度曲线。

当变量较多时，还需要一种方式组织这些依赖关系。**概率图模型** (probabilistic graphical model) 用图表示多个变量的概率关系：节点代表随机变量，连线及其缺失表达分布如何分解、哪些变量在给定条件下相互独立。这里的条件独立表示：给定某些变量后，得知另一个变量的值，不再改变所考察变量的条件分布。这种结构有助于分解计算，不过复杂图中的推断仍可能需要近似方法。概率图的具体定义与计算将在第三卷“模型”的“概率图模型”部分展开⁵。

⁵ I. Goodfellow, Y. Bengio, A. Courville, *Deep Learning*, MIT Press, 2016

参数的点估计与贝叶斯推断 前一小节讨论的是模型参数给定以后怎样进行概率计算。回到训练过程，还需要决定怎样根据数据确定这些参数。一种做法是选择一组具体数值，例如估计温度模型的权重与噪声方差，然后用这组数值预测。用一个值表示每个未知参数，称为**点估计** (point estimation)。前面介绍的似然准则可以用于这一选择：在允许的参数范围内寻找使似然最大的取值，称为**最大似然估计** (maximum likelihood estimation)。参数取确定值之后，温度仍然由一个分布描述；确定的是分布的参数，并非明天的温度。

如果训练数据很少，不同参数都可能合理地解释已有观测。这时可以进一步用分布描述参数的不确定性。**贝叶斯推断** (Bayesian inference) 用数据更新关于未知量的概率描述。对于模型参数，**先验分布** (prior distribution) $p(\theta)$ 表达观察本批数据之前的假设；结合数据 $\mathcal{D}$ 之后，得到**后验分布** (posterior distribution) $p(\theta | \mathcal{D})$ 。预测时，不只采用一组参数，而是将不

同参数给出的结果按后验权重综合起来：

$$p(y | \mathbf{x}, \mathcal{D}) = \int p(y | \mathbf{x}, \theta) p(\theta | \mathcal{D}) d\theta. \quad (2.10)$$

在温度例子中，固定参数下的分布描述相似气象条件仍可能对应不同温度；参数后验还反映了有限数据使我们难以确定预测关系。这两个来源都可以影响最终的预测区间。贝叶斯推断将概率推断用于参数，代价是通常需要额外计算或近似参数后验。

同一个概率模型因此有两种参数处理方式：用点估计固定分布，或用参数后验综合不同分布。概率图中的变量有概率描述，也不要求所有分布参数都采用后一种处理。两种选择还可以与不同容量结合：固定成分数的GMM是参数化概率模型；**高斯过程**（Gaussian process）对可能的函数建立概率描述，不预先把所有函数限制在固定数量的系数中，是非参数化概率模型的例子。非参数化所讨论的表示规模，与是否建立概率分布可以分别选择⁶。

⁶ C. E. Rasmussen, C. K. I. Williams, *Gaussian Processes for Machine Learning*, MIT Press, 2006

概率描述带来了什么 建立分布与进行推断增加了计算，得到的概率信息能帮我们作什么决定？例如，两个模型都预测明天 22°C，但一个把大部分概率集中在 21 到 23°C，另一个分布在更宽范围内。安排对温度敏感的活动时，这两种预测提供的信息不同。GMM 给出的组别概率也能帮助发现难以明确归类的样本。

这些信息是否可靠，要用未参与训练的数据检验。若模型反复给出名义覆盖概率为 90% 的预测区间，就应检查实际温度是否在大约 90% 的情况下落入相应区间。在覆盖率相当的前提下，区间更窄通常能提供更具体的判断。始终给出很宽的区间虽然容易覆盖真实值，却提供不了多少判断依据。因此，评价概率模型既要看中心预测是否准确，也要看不确定性的太小是否与实际误差相称。

分布假设也会限制效果。例如，若同类条件下的温度存在两个明显峰值，单个高斯分布可能把均值放在两个峰之间，并给出不合适的区间。聚类时，错误的群组形状假设也会影响分配概率。概率模型增加了描述和使用不确定性的能力，是否改善具体任务，仍取决于这些假设与数据是否吻合，以及分布能否得到可靠估计。

2.4 变量的关系形式

给定一个输入，模型究竟通过什么关系算出结果？即使都输出温度，预测也可以随着某个特征按固定幅度变化，或在不同范围内采用不同的变化规律。这是模型结构关心的问题。数值预测可以考察预测函数，分类可以考察得分或决策边界，降维可以考察输入到低维坐标的映射。判断线性与非

线性之前，需要明确正在看哪一条关系。

2.4.1 线性结构

一种直接的假设是：每个特征的作用可以用固定权重表示，再把各项贡献相加。线性回归正是将 d 维输入 $\mathbf{x}$ 按权重 $\mathbf{w} \in \mathbb{R}^d$ 加权求和，加上偏置 b ，得到预测值：

$$\hat{y} = \mathbf{w}^\top \mathbf{x} + b = \sum_{j=1}^d w_j x_j + b. \quad (2.11)$$

固定其他特征后， x_j 每增加一个单位，预测值都改变 w_j 。例如，用面积预测房价时，线性关系假设每增加一平方米带来的预测增量相同。严格说，带常数项 b 的关系称为仿射关系；机器学习中通常也将它归入线性模型。

概率需要落在零与一之间，任意的加权和却没有这个限制。逻辑回归在加权和之后加上一个转换函数。对于二分类，记正类概率为 p ，则

$$p = \frac{1}{1 + \exp[-(\mathbf{w}^\top \mathbf{x} + b)]}, \quad \log \frac{p}{1-p} = \mathbf{w}^\top \mathbf{x} + b. \quad (2.12)$$

左式将任意实数得分转为零与一之间的概率。右式来自对左式的变形： $p/(1-p)$ 比较正类与负类的概率大小，再取对数，就得到**对数几率** (log odds)。这个量仍然是输入的仿射函数。用 $p = 0.5$ 作分类阈值时，两类概率相等，对数几率为零，边界因而满足 $\mathbf{w}^\top \mathbf{x} + b = 0$ ，在二维平面中就是一条直线。逻辑回归因此属于线性分类模型，尽管其输出概率包含非线性函数。

这里的线性描述的是对数几率与边界，在线性回归中描述的则是预测值。基础**感知机** (perceptron) 也用加权和作为分类得分，按得分的正负判断两类。它与线性 SVM 的训练准则不同，却都用一个线性分界面完成二分类。

线性结构也可以用于表示学习。PCA 的线性体现在投影上：固定均值与投影方向后，每个低维坐标都是输入减去均值后的加权和。PPCA 增加了分布假设，但从低维表示到观测均值的关系仍然是线性的。因此，线性结构既能用于数值预测和分类，也能用于降维与概率建模。

聚类没有预设的类别边界，但把样本分给最近中心时也会产生分界。对于 K-means 的两个中心 μ_1 与 μ_2 ，边界上的样本满足 $\|\mathbf{x} - \mu_1\|_2^2 = \|\mathbf{x} - \mu_2\|_2^2$ 。展开两边并消去共同的 $\mathbf{x}^\top \mathbf{x}$ 项，得到

$$2(\mu_2 - \mu_1)^\top \mathbf{x} = \|\mu_2\|_2^2 - \|\mu_1\|_2^2. \quad (2.13)$$

这是关于输入的仿射方程，所以标准 K-means 任意两个不同中心之间的分配边界是线性的。但样本到中心的平方距离是二次函数，最终的簇编号也不是输入的线性函数。后文将 K-means 放在线性一侧时，专指这种两两

分配边界。

判断线性结构时，还要明确模型相对于哪一组输入特征是线性的。若先把 x 变成 x^2 ，再计算 $wx^2 + b$ ，模型对新特征 x^2 是线性的，对原始输入 x 则是非线性的。本章以原始输入中的关系为主要依据。“参数以线性方式出现”与“预测对输入是线性的”需要结合具体公式区分。

2.4.2 非线性结构

上一节的模型用一个仿射关系连接输入与所考察的量，但现实中的许多关系会随条件改变。车辆速度增加时，刹车距离通常不会按固定增量增长；同一种药物增加剂量，在不同剂量区间可能产生不同幅度的作用；邮件中的促销词是否可疑，也可能取决于同时出现了多少外部链接。这些关系需要表达弯曲、阈值或特征之间的共同作用。

沿用上一节的判断依据，如果所考察的预测值或得分无法写成原始输入的仿射函数，就属于非线性关系。对于二分类，无法用单一超平面表示的弯曲或分段边界，也需要非线性结构。图2.4展示了线性与非线性关系在回归和分类中的区别。下排保持两类样本不变：一类位于中心，另一类环绕它。任何直线都会把至少一部分样本分错，径向弯曲的边界却可以将两类分开。

图中的弯曲关系可以由不同模型得到。固定次数的多项式回归对原始输入是非线性的，但只需固定数量的系数，属于参数化模型。高斯过程回归同样可以表达弯曲关系，却不受固定有限维系数限制，还为函数值建立概率分布。曲线的形状说明了关系形式；它本身没有告诉我们参数化方式与表示规模、概率语义如何选择。

非线性也不只表现为单个变量对应一条弯曲曲线。若模型包含 x_1x_2 ，那么 x_1 对输出的影响会随 x_2 而改变，这称为特征之间的交互。回到邮件例子，少量促销词本身可能并不可疑，但当外部链接很多时，同样数量的促销词可能明显提高垃圾邮件得分。单独查看两个特征时，这种共同作用不一定明显；把它们放在同一关系中，才会看到线性加权和无法表达的条件变化。

是否需要非线性结构，应结合任务和数据判断。线性模型提供了清楚的基准：每个特征通过固定权重影响所考察的量。若验证数据表明误差仍随输入区域呈现稳定的弯曲、阈值或交互模式，再引入分段规则或非线性变换会有依据。更灵活的结构扩大了可表达的关系，也需要结合数据量与结构约束，防止把偶然波动当成规律。常见的做法是按条件划分区域，或为输入增加非线性变换。




图 2.4 线性与非线性关系的几何示意。上排依次为线性预测与非线性预测，下排用同一组环形样本对照线性 SVM 的限制与二次核 SVM 的表达能力；圆点和方点代表两类。左图虚线只展示一条候选直线，空心圈标出按其左右类别分配时的错分方点，不代表最优 SVM 解。外圈方点的凸包包含内圈圆点，故任何直线都不能完全分离这组样本。右图以圆心为坐标原点，半径 8 的边界可由二次核 $\kappa(\mathbf{u}, \mathbf{v}) = (\mathbf{u}^T \mathbf{v})^2$ 与偏置表示。图为几何构造，非训练结果。

按条件采用不同规则 表达非线性的一种直接办法，是先划分输入空间，再在不同区域使用不同规则。决策树通过一系列条件判断，将不同输入交给不同规则处理。例如，先检查促销词数量；只有数量达到阈值时，再检查外部链接数。一条从根到叶的路径对应一组条件，不同叶节点对输入空间的不同区域给出预测。图2.5将同一组规则画成树与平面分区。

常见决策树每次只比较一个特征与一个阈值，在叶节点输出固定值。单次比较虽然简单，多次分支组合后却能形成分段的预测关系和复杂边界。这种方式便于表达“在某种条件下采用某条规则”，但相邻区域的预测也可能出现跳变。若允许叶节点数随训练数据增加，树属于非参数化设定；若预先限制叶节点数量，表示规模也就受到固定上限约束。这是结构与容量需要分别考察的一个例子。

对输入进行非线性变换 除了显式划分区域，还可以先变换输入，再计算输出。例如，加入 x_1^2 可以表达弯曲关系，加入 $x_1 x_2$ 可以表达两个特征的




图 2.5 按条件分情况处理输入。左侧为判断树，右侧为对应的输入区域。该教学例子在 $x_1 \geq 2$ 且 $x_2 \geq 1$ 时输出类别 1，其余区域输出 0。

共同作用。用 $\phi(\mathbf{x})$ 表示变换后的特征，得分可写为

$$s(\mathbf{x}) = \mathbf{w}^\top \phi(\mathbf{x}) + b. \quad (2.14)$$

只要变换包含非线性关系，线性得分就可能在原始空间中对非线性边界。例如，中心区域是一类、外围是一类时，可以把到原点的平方距离 $x_1^2 + x_2^2$ 作为新特征，再用一个阈值区分两类。

核方法 (kernel methods) 也使用这种思路：通过计算样本在特征空间中的内积，间接使用变换后的关系，无需逐项列出所有新特征。线性核仍对应线性结构，高斯核等非线性核则能够形成弯曲边界。标准高斯核 SVM 可以随样本增加保留更多表示系数，属于非参数化设定；若预先选取固定数量的变换特征进行近似，则成为另一种容量设定⁷。

手工选择 x^2 或 x_1x_2 ，要求我们预先猜测哪些变换有用。神经网络让中间变换也参与学习。与基础感知机只有一个线性得分相比，多层网络在中间层加入非线性函数，通常称为 **激活函数** (activation function)；例如，把负值置零、保留非负值，就能让不同输入范围采用不同的计算关系。网络将多次变换组合起来，根据训练目标共同调整中间表示和最终预测。如果各层都只有加权求和而没有非线性操作，把前一层代入后一层以后，仍能合并成一次加权求和与偏置。因此，仅仅增加这类层数并不能得到非线性关系。

树直接划分区域，便于表达条件规则；特征变换则改变输入表示，使弯曲关系或共同作用可以通过新的特征表达。两种思路也会交叉，例如神经网络的分段线性激活同样把输入划分成不同计算区域。能否把这些表达能力用于新样本，仍取决于数据、结构限制与训练方法。

神经网络与前文的概率图模型都可以画成图，但图中的连线承担不同作用：网络连线说明数值如何参与下一步计算，概率图的连线及其缺失说明变量间的概率依赖。一个概率模型可以用神经网络计算分布参数；此时

⁷ C. Cortes, V. Vapnik, *Support-Vector Networks In Machine Learning*, 1995, vol. 20, no. 3, pp. 273–297

非线性计算结构与概率描述就在同一个模型中结合起来。

2.5 输出的形式与含义

模型内部采用的关系已经确定，交给使用者的结果却仍有选择。温度模型可以返回一个数，也可以返回一个区间或完整分布；分类器可以返回类别，也可以保留各类概率。理解输出时需要回答两个不同问题：结果怎样组织，以及这些数值代表什么。前者区分标量、向量和带有位置或顺序的结构化对象；后者区分点预测、类别编码、分布摘要、完整分布和采样结果。只看其中一项，不能确定模型向使用者提供了哪些信息。

2.5.1 输出的组织形式

标量输出 用一个数表示结果，便是**标量输出**（scalar output）。温度预测、价格预测和某个商品的评分都可以采用这种形式。这类数值具有对应的单位或尺度，例如 22°C 可以直接用于温度比较。

同样的标量形式也可以编码离散结果。邮件分类可以用 0 表示正常、1 表示垃圾邮件；聚类可以用 $1, 2, \dots, k$ 区分不同群组。分类编号的语义由标签定义，聚类编号则标记从数据中发现的群组。交换两个簇的编号不会改变分组结果，因此编号之间的数值差通常没有距离意义。

向量与结构化输出 当一个结果需要同时保留多个分量时，可以把它们按顺序组成**向量输出**（vector output）。例如，同时预测温度、湿度和风速，得到三个数值；预测未来七天的温度，得到按日期排列的七个数值。各分量对应不同目标，使用时需要知道它们的顺序、单位和含义。

另一类向量用来表示输入本身。PCA 输出的每个坐标表示样本沿一个投影方向的位置；神经网络也可以把一张图像变成一个特征向量，并通过适当的训练目标让内容相近的图像具有相近的表示。这些向量随后可以用于检索、分类或聚类，而不必直接对应某个最终答案。

图像重构也可以看作输出一组数值，只是它们按像素位置和颜色通道排列成数组。文本输出则还带有符号顺序与长度等组织信息。讨论这类结果时，除了分量的取值，还需要保留它们之间的位置、顺序或连接关系。

标量、向量和结构化对象只说明结果怎样组织，不说明其中数值的含义。长度为三的向量可能表示三个温度预测，也可能表示三个类别的概率；后者还要求各分量非负、总和为一。同样，一个标量既可能是温度预测，也可能只是类别或簇的编号。要继续理解输出，还要说明这些数值代表一个直接结果、对分布的概括，还是完整的概率描述。

2.5.2 输出的含义

第2.3节考察模型是否建立概率分布；这里进一步考察接口是否把完整分布交给使用者，还是只返回一个结果或摘要。模型内部的概率语义与接口交付的信息有关，却不是同一个判断。

点结果与分布摘要 模型可以直接返回一个点预测、类别或簇编号。概率模型也可以只交付一个便于使用的摘要：逻辑回归能够返回概率最大的类别，高斯温度模型能够返回分布均值或预测区间。这些输出分别可能采用标量、向量或区间等形式，但都没有把模型保留的全部概率信息交给使用者。摘要便于比较和决策，代价是其他可能结果及其概率不再完整可见。

概率分布与采样 如果需要知道各个可能结果分别有多大概率，模型就要提供**概率分布输出**（probability distribution output），保留各种结果的可能程度。对于有限类别，可以逐项给出非负、总和为一的概率。例如，邮件分类输出 $(0.2, 0.8)^T$ ，表示正常邮件与垃圾邮件的概率分别为 0.2 和 0.8。相比只返回“垃圾邮件”，这一结果还体现了模型对判断的确定程度。

连续变量有无穷多个可能取值，通常用分布的形式和参数来表示。例如，温度模型指定高斯分布，并输出均值 22 和方差 4，就确定了相应的密度曲线。密度曲线下某个区间的面积给出温度落入该区间的概率；曲线在某一点的高度表示密度，并不是温度恰好等于该数值的概率。

同一个概率模型可以提供不同接口：直接返回预测结果的概率分布，计算前述摘要，或者从分布中采样。对于温度预测，摘要可以是均值 22°C ，也可以是具有指定覆盖概率的预测区间；采样则可能得到 21.3°C 等一个可能的温度。对于图像生成，模型的一次采样得到一张图像，多次采样可以得到不同图像。分布保留各种可能结果，摘要便于概括和决策，采样则用于展示或模拟具体情形。

输出的组织形式与结果含义因此是两条不同的描述轴。类别分布用向量表示，分布均值用标量表示，一次采样则可能产生高维数组。说明返回了几个数之后，还要说明这些数代表点预测、分布摘要、完整分布，还是从分布中取出的一个样本。

2.6 损失与学习准则

知道模型要输出什么，还不足以开始训练：我们需要约定怎样判断某个结果更好。例如，分类与聚类都可以把邮件特征映射为一个编号。分类已有真实标签，希望预测类别与标签一致；聚类没有这样的标签，需要根据样本之间的关系形成分组。两者返回的都是编号，学习时评价结果的依据却不同。

本节按评价所依赖的信息组织三类问题。有直接目标时，可以逐个样本比较模型输出与目标，再根据输出对象选择数值、向量或概率分布的差异。若没有逐样本答案，或者任务还关心多个样本与表示之间的关系，就需要规定紧凑性、样本到分类边界的距离、相对邻近或低维结构。当前行动还会影响后续结果时，评价范围则要扩展到整段轨迹和长期收益。这些准则可以合用，例如 PCA 既限制表示所在空间的维数，又衡量重构向量与原始输入的误差。

2.6.1 逐样本的目标差异

先看单个结果有已知答案的情形。温度、价格和销量预测都有一个可以比较的目标值；分类也有待预测的真实类别。这类任务希望模型的结果接近已知答案，但连续数值与离散类别需要不同的比较方式。记第 i 个样本的真实值为 y_i 、预测为 $\hat{y}_i$ ，通常先计算每个样本的损失，再取 n 个样本上的平均值。

连续数值 预测温度偏高两度与偏低两度，都有两个单位的偏差。为了避免正负误差在求和时互相抵消，可以用平方损失或绝对损失评价单个预测：

$$\ell_{\text{sq}}(\hat{y}, y) = (\hat{y} - y)^2, \quad \ell_{\text{abs}}(\hat{y}, y) = |\hat{y} - y|.$$

分别在样本上取平均，就得到第 1.5 节介绍的均方误差和平均绝对误差。若实际温度为 20、预测为 22，单个样本的平方误差为 4，绝对误差为 2。当预测偏差由 2 增至 4，平方误差变成原来的四倍，绝对误差则变成两倍。平方误差更重视较大的偏差，且作为预测值的函数处处可导；绝对误差对少数大偏差更稳健，但在误差为零处不可导，优化时需要相应处理。

如果真实错误的代价不对称，还可以分别设置高估和低估的损失。例如，备货不足与库存过多的成本不同，选择误差形式时就应体现这种差别。因此，“接近真实值”还需要进一步说明：哪些方向、多大程度的偏离更值得惩罚。

离散类别 离散数值通常用于编码类别，而类别编号只表示身份。若 1、2、3 分别代表猫、狗和鸟，编号之差不能衡量分类错误的严重程度。最直接的**零一损失**（zero-one loss）只检查预测是否正确：

$$\ell_{01}(\hat{y}, y) = \begin{cases} 0, & \hat{y} = y, \\ 1, & \hat{y} \neq y. \end{cases} \quad (2.15)$$

它在数据集上的平均值就是分类错误率。不过，只要预测类别没有改变，参数调整得再多，零一损失也保持原值，因而难以指引连续参数怎样更新。

训练时常改用随得分或概率变化的**代理损失** (surrogate loss), 用更便于优化的目标帮助减少分类错误。常见选择包括后文介绍的类别概率交叉熵, 以及第2.6.2节用于控制样本到分类边界距离的代理损失。如果不同类型的误判具有不同代价, 也可以用事先给定的代价表替代统一的 1。

向量的差异 当目标由多个分量组成时, 需要比较两个向量而不是两个标量。图像去噪希望输出接近干净图像, 压缩与重构希望恢复的内容接近原始输入, 多变量预测希望一组预测共同接近真实观测。这些任务都有两个需要比较的向量。表示学习也会比较向量: 例如, 让同一图像的不同视图得到相近的特征表示。前者通常关心每个分量恢复得怎样, 后者则可能更关心整体方向或相对位置。

对于预测向量 $\hat{\mathbf{y}}$ 与目标向量 $\mathbf{y} \in \mathbb{R}^m$, 常用的两种误差为

$$\ell_2(\hat{\mathbf{y}}, \mathbf{y}) = \|\hat{\mathbf{y}} - \mathbf{y}\|_2^2 = \sum_{j=1}^m (\hat{y}_j - y_j)^2, \quad (2.16)$$

$$\ell_1(\hat{\mathbf{y}}, \mathbf{y}) = \|\hat{\mathbf{y}} - \mathbf{y}\|_1 = \sum_{j=1}^m |\hat{y}_j - y_j|. \quad (2.17)$$

平方欧氏误差将各分量的平方偏差相加, 较大偏差占更高权重; L_1 误差累计绝对偏差, 较少被个别异常分量主导。两者都依赖分量的尺度, 例如同时比较温度与气压时, 需要考虑单位差异, 决定是否先做缩放或设置权重。

若主要关心方向, 可以使用**余弦相似度** (cosine similarity), 即两个向量夹角的余弦值: 方向越接近, 这个值越大。对于非零向量 $\mathbf{a}$ 与 $\mathbf{b}$, 相应的损失为

$$\ell_{\cos}(\mathbf{a}, \mathbf{b}) = 1 - \frac{\mathbf{a}^\top \mathbf{b}}{\|\mathbf{a}\|_2 \|\mathbf{b}\|_2}. \quad (2.18)$$

同向向量的损失为零。例如, $(1, 2)^\top$ 与 $(2, 4)^\top$ 长度不同, 但方向相同, 所以余弦损失为零, 欧氏误差却不为零。图2.6展示了这一差别。比较文档或图像的特征表示时, 这种对长度变化不敏感的度量可能有用; 若向量的幅度表示真实温度、亮度或数量, 忽略长度就可能丢失任务所需的信息。

还需要判断数值误差能否代表任务中的相似程度。例如, 一张图像仅平移一个像素, 内容可能几乎没变, 却会造成许多像素值不一致。直接比较像素适合要求位置精确对应的重构; 若关心物体内容, 可以先提取相应特征, 再比较特征向量。度量与所比较的表示需要一起选择。

概率分布的差异 如果模型输出概率分布, 只比较最终类别或分布均值会丢失其余概率信息。邮件分类可能不仅要求类别正确, 还要求预测概率可信; 学习数据分布时, 希望模型描述的样本出现规律接近实际数据; 让一个模型模仿另一个模型时, 也可能希望两者给出的类别概率接近。这些任




图 2.6 两种向量比较方式关注不同差异。左侧比较两个端点之间的距离，右侧比较向量方向之间的夹角。同向但长度不同的向量，余弦损失为零，欧氏误差仍大于零。

务比较的是概率分布，而不只是最终选出的一个答案。

先考虑有限类别。设目标分布为 $\mathbf{p} = (p_1, \dots, p_k)^\top$ ，预测分布为 $\mathbf{q} = (q_1, \dots, q_k)^\top$ ，二者的分量都非负且分别求和为一。模型给某一结果的概率越低， $-\log q_j$ 就越大；再按目标分布中该结果的概率 p_j 加权，就得到**交叉熵** (cross-entropy)。它衡量模型对目标分布下的结果平均赋予了多大的负对数概率：

$$\text{CE}(\mathbf{p}, \mathbf{q}) = - \sum_{j=1}^k p_j \log q_j. \quad (2.19)$$

如果已知样本属于类别 c ，可以令 $p_c = 1$ 、其余分量为零；这种编码称为**独热表示** (one-hot representation)。此时交叉熵就是 $-\log q_c$ 。给正确类别 0.9 的概率比给 0.1 的损失更小；当 q_c 趋近零时，损失趋向无穷大，因而非常自信却判错的预测会受到强烈惩罚。这里的对数采用自然底数。

交叉熵在预测分布等于目标分布时，也未必为零。如果希望用零表示两个分布完全一致，可以减去目标分布与自身的交叉熵。

两者相减得到**KL 散度** (Kullback-Leibler divergence)，用来衡量两个分布的差异：

$$D_{\text{KL}}(\mathbf{p} \parallel \mathbf{q}) = \sum_{j=1}^k p_j \log \frac{p_j}{q_j}. \quad (2.20)$$

约定 $p_j = 0$ 的项为零；若 $p_j > 0$ 而 $q_j = 0$ ，散度为无穷大。它非负，并在两个分布相同时为零。把式(2.20)中的对数比值拆开，就得到 $D_{\text{KL}}(\mathbf{p} \parallel \mathbf{q}) = \text{CE}(\mathbf{p}, \mathbf{q}) - \text{CE}(\mathbf{p}, \mathbf{p})$ 。固定目标 $\mathbf{p}$ 时，第二项不随预测 $\mathbf{q}$ 变化，所以最小化 KL 散度与交叉熵会得到相同的优化要求。KL 散度通常不对称：交换目标与预测，关注的概率区域和得到的数值都可能改变。

也可以直接比较概率向量的平方差。对于独热目标，这就是**Brier 评分**

(Brier score):

$$\ell_{\text{Brier}}(\mathbf{p}, \mathbf{q}) = \sum_{j=1}^k (q_j - p_j)^2. \quad (2.21)$$

按这里的求和定义，它位于 0 到 2 之间。相比交叉熵，它对极端错误的惩罚有上限，因此两者会对少数非常自信的错误赋予不同权重。Brier 评分可以用来训练或评价概率预测，是较早用于概率预报的准则之一⁸。

学习整个数据分布时，真实分布通常未知，只能得到样本。设模型密度为 $p_{\theta}(\mathbf{x})$ ，常用平均负对数似然作为目标：

$$\ell_{\text{NLL}}(\theta) = -\frac{1}{n} \sum_{i=1}^n \log p_{\theta}(\mathbf{x}_i). \quad (2.22)$$

它要求模型对已观测数据给出较大的概率或密度，适用于 GMM 等分布模型。在独立同分布采样、相关期望有限等条件下，样本平均估计总体的期望负对数似然；最小化该总体目标等价于减小真实分布到模型分布的 KL 散度。若建模的是给定输入后的类别分布 $p_{\theta}(y | \mathbf{x})$ ，其负对数似然则对应上面的分类交叉熵。

交叉熵与 KL 散度在目标固定时给出相同的优化方向，Brier 评分则改变了对极端错误的权重。这些度量对不同类别的处理通常只依据概率大小，不自动考虑类别在空间上相距多远。如果任务关心“概率质量移动到了多远的位置”，还需要将结果之间的距离纳入比较。

2.6.2 关系与结构准则

逐样本差异要求输出接近给定目标，但有些任务没有这样的答案，或者还要约束多个样本、参数与表示之间的关系。聚类希望同组样本聚在一起，检索希望相关样本比不相关样本更近；分类可以在预测正确之外要求样本与边界保持一定距离，降维则可以要求表示落在低维空间中。这里把这些要求归为关系与结构准则，其中既有必须满足的限制，也有由损失鼓励的几何性质。

样本到中心的距离 K-means 用 k 个中心近似数据，最小化样本到最近中心的平方距离：

$$\min_{\mu_1, \dots, \mu_k} \frac{1}{n} \sum_{i=1}^n \min_{1 \leq j \leq k} \|\mathbf{x}_i - \mu_j\|_2^2. \quad (2.23)$$

内层为每个样本选择中心，外层调整中心位置。这里没有真实类别作为参照，簇编号是减小几何误差的结果。平方距离使较远的样本影响较大，也偏好用围绕中心的紧凑区域表示群组。若改用 L_1 距离，给定分组时的中心变为各坐标的中位数，通常更能抵抗少量远离群组的点；若主要关心方向，则可以使用基于余弦相似度的聚类目标。

⁸ G. W. Brier, *Verification of Forecasts Expressed in Terms of Probability* In *Monthly Weather Review*, 1950, vol. 78, no. 1, pp. 1–3

标准 K-means 直接优化的是簇内紧凑程度，没有要求任意两个簇之间的距离都尽量大。当中心取各簇均值时，固定数据的总平方离差可分成簇内与簇间两项，减小簇内项也会增大簇间项；但后者描述各中心相对总体均值的分散程度，并不保证每对簇都充分分离。

样本到分类边界的间隔 SVM 关心正确分类之外还能留出多大的**间隔** (margin)。这里的间隔要求样本不仅位于分类边界的正确一侧，还要与边界保持一定距离。对于 $y \in \{-1, +1\}$ 和得分 $f(\mathbf{x}) = \mathbf{w}^\top \mathbf{x} + b$ ，常用**合页损失** (hinge loss) 为

$$\ell_{\text{hinge}}(y, f(\mathbf{x})) = \max\{0, 1 - yf(\mathbf{x})\}. \quad (2.24)$$

当样本在正确一侧且得分达到规定余量时，损失为零；分类错误或余量不足时，损失增加。但只把得分放大，也可能降低合页损失，几何边界却完全没动。线性 SVM 因此把这一损失与 $\|\mathbf{w}\|_2^2$ 的惩罚结合。对于 $\mathbf{w} \neq \mathbf{0}$ ，样本的有符号几何距离是 $yf(\mathbf{x})/\|\mathbf{w}\|_2$ ；当得分余量固定为 1 时，较小的权重范数对应较大的几何间隔。两项共同权衡间隔违反与间隔大小。它利用类别标签组织空间，无需让同类样本都围绕同一个中心。

相关样本之间的相对距离 检索与表示学习常只要求相对次序：同一物体的两张照片，应比不同物体的照片更接近。设 $\mathbf{a}$ 为待比较样本的表示， $\mathbf{p}$ 为相关样本的表示， $\mathbf{n}$ 为不相关样本的表示， d 为选定距离， $m > 0$ 为所需余量。将一个参照样本、一个相关样本和一个不相关样本放在一起比较，可以得到**三元组损失** (triplet loss)：

$$\ell_{\text{triplet}} = \max\{0, d(\mathbf{a}, \mathbf{p}) - d(\mathbf{a}, \mathbf{n}) + m\}. \quad (2.25)$$

当相关样本至少比不相关样本近 m 时，损失为零；否则就按不足的差额计入损失。它不规定所有表示必须落在某个固定中心附近。这种目标适合学习距离关系，但效果依赖所选距离、样本配对和余量：过于容易的比较几乎不提供学习信号，错误配对则可能把不该靠近的样本拉到一起。图2.7对照了中心距离、分类间隔与相对距离三种要求。利用已知相似关系学习表示或距离，是**度量学习** (metric learning) 的基本思路⁹。

PCA 则限制表示所在空间的维数，并在这个限制下减小重构误差。这些例子说明，选择空间目标需要先明确希望保留什么：中心距离强调紧凑性，分类间隔强调两类的分离，相对距离强调邻近次序，低维约束强调表示的压缩。同一个模型也可以同时使用其中几种要求。

⁹ K. Q. Weinberger, L. K. Saul, *Distance Metric Learning for Large Margin Nearest Neighbor Classification* In Journal of Machine Learning Research, 2009, vol. 10, no. 9, pp. 207–244




图 2.7 三种几何要求。左侧缩短样本到所属中心的距离；中间让带标签样本与分类边界保持间隔；右侧要求相关样本比不相关样本更接近参照样本。三者分别比较不同的几何对象。

2.6.3 轨迹与长期目标

单次输出的误差还不能评价所有任务。机器人导航时，眼前距离终点更近的一步可能把它带入死路，暂时绕行反而能更早到达。游戏决策和连续资源调度也有类似的问题：当前动作会影响后续状态与奖励。评价这类模型，需要把整段行动过程计入，并考虑环境和动作选择带来的多种可能经历。

一套根据当前信息选择动作的规则会与环境共同产生整段轨迹。常见准则先把一条轨迹中的多步奖励合成总回报，再对各种可能轨迹取平均；也可以评价长期运行中的单位时间平均回报。这些选择改变了哪些后果受到重视，不能由某一步的即时误差代替。第 3.3 节将在建立状态、动作、奖励和策略等概念后，正式写出相应目标。

无论选择哪种回报，仅比较期望都可能掩盖结果的波动；若任务还要求控制失败概率，需要另加相应约束。轨迹长、罕见事件多时，有限次交互对长期表现的估计也可能不稳定。

强化学习系统内部仍可以训练数值预测模型，例如让价值模型预测未来累计回报，并用平方误差评价预测。这个局部损失服务于整体决策目标。还要区分“输出具有序列形式”与“目标评价一整段决策过程”。例如，预测句子的下一个词虽然产生文本序列，却可以逐位置比较类别概率，仍属于概率分布拟合。

从逐样本误差到整段轨迹的期望，上述目标都在说明“什么结果更好”；梯度下降、交替更新等算法则说明“怎样改善结果”。这种改善也可能只发生在局部：决策树逐步选择分裂条件，每一步都评价候选分裂，却未必在优化一个关于整棵树的单一全局目标。近邻分类甚至可以直接保存样本，把主要计算留到查询时。比较模型时，除了写出准则，还需要说明它用于整个模型，还是某一步局部选择。

2.7 模型维度的交叉与组合

前面的例子已经多次遇到维度交叉：一个非线性模型仍可以只有固定数量的参数，一个概率模型也可以只返回一个数。现在把这些选择放回完整任务中，看看改变某一项设定，会保留哪些性质，又会牵动哪些选择。

2.7.1 模型维度的组合

仍以根据气象特征预测明日温度为例。固定输入表示以后，一个完整的基准方案可以是：用固定数量的权重计算输入的仿射函数，直接返回一个温度数值，并用平方误差训练。沿五个维度描述，它是参数化、非概率且采用线性结构的模型，输出接口返回标量。平方误差作为学习准则，衡量预测值与真实温度的差异。这些性质都来自具体设定，任务名称本身只说明我们要预测什么。

保留这个任务，改变预测的描述方式。若仍用仿射函数计算高斯分布的均值，并额外估计一个方差参数，模型仍属固定维参数化模型，但表示规模增加；关系形式保持不变，概率语义改为描述温度分布，损失与学习准则也相应改为评价观测数据的似然。

也可以保留点预测，改用含非线性激活的固定结构神经网络。此时参数化方式仍为参数化，关系形式变为非线性；如果让网络输出分布参数，又得到非线性的概率预测。近邻回归依赖不断增加的训练实例，可以形成非参数化的非概率模型；高斯过程同样不受固定有限维系数限制，却对可能的函数和预测结果建立概率分布。

这些组合要求输出接口、关系形式和损失与学习准则相互配合。标量温度可以用绝对误差或平方误差评价；类别分布可以用交叉熵或 Brier 评分评价；类别编号只表示身份，直接相减没有误差意义。如果模型还预测方差，仅用均值的误差就无法评价它提供的全部信息。

关系形式也会影响损失与学习准则的选择。K-means 用有限个中心表示群组，以样本到中心的距离衡量簇内紧凑性；PCA 把表示限制在低维子空间中，在这个约束下评价重构误差。把五个维度放在一起，是为了检查参数化方式与表示规模、概率语义、关系形式、输出接口和损失与学习准则能否共同完成任务。

2.7.2 分类模型的五维比较

把这些问题用于分类，可以检验章首提到的权重、规则树与近邻究竟差在哪里。表2.2列出九种具体设定。阅读时可以沿着一列比较同一属性，也可以沿着一行检查一个完整模型的各项选择。

表中有两处设定需要说明。前文的高斯判别分析用各类的高斯分布计

算类别后验；其中 **协方差**（covariance）描述各方向上的分散程度和相关性。各类共享同一个非奇异协方差矩阵时，对数后验之差是线性的；各类使用不同协方差时，一般会得到二次边界，称为**二次判别分析**（quadratic discriminant analysis）。朴素贝叶斯则采用特征只取 0 或 1 的伯努利版本，例如某个词是否出现。在各特征条件概率严格位于零与一之间时，其类别对数几率可以写成这些二值特征的线性函数。

具体模型设定	参数化方式与表示规模	概率语义	关系形式	输出接口	损失与学习准则
线性 SVM	参数化	非概率	线性得分	得分、类别	合页损失与权重惩罚
逻辑回归	参数化	概率	线性对数几率	类别概率	条件负对数似然，即分类交叉熵
高斯判别分析，共享协方差	参数化	概率	线性对数后验之差	类别概率	带标签数据的联合似然
伯努利朴素贝叶斯	参数化	概率	二值特征的线性对数几率	类别概率	类别比例与各类内特征的似然
高斯核 SVM	非参数化	非概率	非线性得分	得分、类别	特征空间中的间隔目标
二次判别分析	参数化	概率	一般为二次边界	类别概率	带标签数据的联合似然
固定结构的非线性神经分类器	参数化	概率	非线性得分	类别概率	通常使用分类交叉熵
硬投票 k 近邻	非参数化	非概率	局部投票形成的分段规则	类别	保存样本；查询时按距离选择邻居
硬标签决策树，叶数可增长	非参数化	非概率	条件分支与分段规则	类别	逐步选择使节点内类别更一致的分裂

表 2.2 分类模型的五维比较。表中采用所列的具体版本；概率模型均可进一步返回最大概率类别。“概率语义”按是否建立类别或联合分布判断，不能只由最终是否返回标签判断。

从“关系形式”一列看，线性 SVM、逻辑回归、共享协方差的高斯判别分析和表中的伯努利朴素贝叶斯都能得到线性得分或线性对数几率，而且都由预先确定数量的参数描述。它们在关系形式、参数化方式与表示规模上相近，概率语义和损失与学习准则却不同。线性 SVM 不建立类别分布，而是用间隔目标学习分类得分；逻辑回归直接建立 $p(y \mid \mathbf{x})$ ，用条件负对数似然学习；高斯判别分析和朴素贝叶斯则建立 $p(y)p(\mathbf{x} \mid y)$ ，再由联合分布计算类别后验。画出一条直线还不足以区分这些模型，还要看这条线来自怎样的概率假设与训练准则。

若线性边界不足以区分类别，以上几条路线又有不同的扩展方式。把线性 SVM 的线性核换成高斯核，间隔准则和得分输出仍然保留，但边界可以弯曲，表示规模也可能随支持向量数量增长。高斯判别分析在各类共享协方差时产生线性边界，改为各类使用不同协方差后成为二次判别分析；它仍是参数化概率模型，仍通过联合似然学习，只是边界通常变为二次曲面。逻辑回归与固定结构的非线性神经分类器都可以直接输出 $p(y \mid \mathbf{x})$ 并使用分类交叉熵，但后者通过中间层形成非线性得分。这些扩展增加了非线性表达能力，却不一定改变参数化或非参数化的归类，概率语义也可以保持原样。即使仍属参数化模型，候选关系的范围和容量也可能已经改变。

还可以从样本附近或条件区域内决定类别。硬投票 k 近邻保存训练样

本，在查询时按距离选择邻居；硬标签决策树逐步选择分裂条件，在叶节点给出类别。表中的两个版本都不显式建立类别概率，表示规模也都可以随数据增长，但它们形成非线性的方式并不相同：近邻方法产生局部的分段规则，决策树则把输入空间划分为若干条件区域。它们都能返回类别，学习过程却分别侧重保存与查询规则、以及逐步改善节点内类别一致性。

现在沿输出接口一列回看：SVM 的两个版本都能返回得分，多种关系形式也都能返回类别概率，相同输出接口背后的参数化方式与表示规模、损失与学习准则却可能不同。表中的硬投票与硬标签也是有意选定的版本；若进一步把近邻频率或叶节点类别比例解释为概率估计，概率语义与输出接口两列就需要随之改写。方法名称给出的是一组可能选择，表中的具体设定才决定本次比较的结论。

2.7.3 聚类模型的五维比较

如果邮件没有标签，问题就从“哪一类是正确答案”变成“哪些邮件应当归在一起”。相似可以指离同一个中心近，也可以指属于同一种分布，或由相邻样本连接成一片区域。表2.3列出七种具体设定；它们的差别始于这些分组依据，并进一步影响表示规模与输出。

具体模型设定	参数化方式 与表示规模	概率语义	关系形式	输出接口	损失与学习准则
K-means	参数化	非概率	线性两两分配边界	簇编号	样本到中心的平方距离
高斯核 K-means	非参数化	非概率	非线性分配边界	簇编号	核特征空间中的平方紧凑性
模糊 C 均值	参数化	非概率	隶属度非线性；硬分界线性	隶属度向量、编号	隶属度加权的簇内平方距离
GMM, 共享协方差	参数化	概率	线性两两分配边界	组别概率、编号	观测数据的似然
GMM, 不同协方差	参数化	概率	一般为二次分配边界	组别概率、编号	观测数据的似然
DBSCAN	非参数化	非概率	邻域连通关系	簇编号、噪声标记	邻域密度与连通规则，无统一的误差最小化目标
Ward 层次聚类	非参数化	非概率	逐步合并的层次关系	层次树、截取后的簇编号	每步最小化簇内平方离差的增量

表 2.3 聚类方法的五维比较。参数化设定固定输入维数与中心或成分数。DBSCAN 与层次聚类主要组织已有样本，其邻域和层次关系不直接对应一个线性预测函数。

标准 K-means 从中心出发定义群组，用有限个中心表示数据，以样本到中心的平方距离衡量簇内紧凑性，并返回最近中心的编号；其两两分配边界是线性的，推导见式(2.13)。高斯核 K-means 保留中心与紧凑性这一思路，但改在核特征空间中比较样本与原型，因此原始空间中的边界可以弯曲。使用高斯核时，原型通常通过训练样本表示，表示规模可以随数据增长；它与标准 K-means 都属于非概率模型，却分别采用非参数化的非线性关系形式和参数化的线性分配关系¹⁰。

处于群组交界处的样本，也可以同时与多个中心保持联系。**模糊 C 均值**

¹⁰ I. S. Dhillon, Y. Guan, B. Kulis, *Kernel k-Means, Spectral Clustering and Normalized Cuts* In Proceedings of the Tenth ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 2004, pp. 551–556

(fuzzy c-means) 使用有限个中心和距离目标, 为样本返回各簇的隶属度, 也就是它在各簇中参与计算的程度。隶属度非负且总和为一, 其含义来自加权的簇内平方距离, 并不是由观测概率分布推断得到的组别后验。若只取最大隶属度对应的簇, 分配又回到最近中心判断。它与 K-means 在参数化方式与表示规模、概率语义上相近, 主要区别落在输出接口和损失与学习准则上¹¹。

如果希望归属程度具有概率含义, 就需要为数据建立相应的分布。GMM 以多个高斯分布及其混合比例建立观测数据与潜在组别的联合分布, 通过后验概率表示样本属于各组的可能性, 并用数据似然学习参数。各成分共享同一协方差时, 两成分对数后验之差中的二次项抵消, 得到线性分配边界; 各成分使用不同协方差时, 二次项通常保留, 边界一般为二次曲面。两个版本都是参数化概率模型, 输出接口也都返回组别概率, 关系形式的选择却不同。共享协方差 GMM 与 K-means 都能形成线性两两边界, 但前者给出概率解释并优化似然, 后者只按几何距离分组。这一对比说明, 线性关系形式本身不能决定模型是否具有概率语义。

当群组沿弯曲路径展开时, 单个中心或高斯成分可能难以描述形状。DBSCAN (density-based spatial clustering of applications with noise) 根据局部邻域中的样本数量寻找稠密区域, 再按连通关系扩展群组; 它可以形成弯曲群组, 并把孤立样本标为噪声。这里的“密度”是邻域计数, 不是归一化的观测概率密度, 因此表中的 DBSCAN 是非参数化、非概率模型, 输出包括簇编号与噪声标记¹²。如果希望同时保留不同粗细程度的分组, 可以使用**凝聚层次聚类** (agglomerative hierarchical clustering): 从小群组开始逐步合并, 保留一棵可以在不同层级截取的树。表中的**Ward 方法**每一步选择使簇内平方离差增加最少的合并; 它与 K-means 都重视平方紧凑性, 却输出层次关系而不是一组固定中心¹³。

这些比较给出了几种具体取舍: 希望弯曲的分配边界, 可以从 K-means 改用核表示; 希望保留多重归属, 可以考虑隶属度或组别概率, 并分清二者的含义; 希望保留局部连通形状或不同层级, 则需要邻域关系或合并树。即使最终都截取为一组簇编号, 各方法保留的信息和认定“应当归在一起”的理由仍然不同。

2.7.4 模型组合与选择

前两个小节分析的是单个模型的维度组合, 实际系统还可能把多个模型或表示模块连接起来。这时除了判断各模块的属性, 还要考察它们怎样协作。例如, 先用 PCA 压缩邮件特征, 再用 K-means 分组, 是把表示与聚类串联; 先用神经网络学习表示, 再接一个线性分类器, 是把非线性特征计算与线性得分结合起来。后一个模型虽然最后一层是线性的, 整体对原始输入通常仍然是非线性的。

¹¹ J. C. Bezdek, R. Ehrlich, W. Full, *FCM: The Fuzzy c-Means Clustering Algorithm In Computers & Geosciences*, 1984, vol. 10, no. 2-3, pp. 191-203

¹² M. Ester, H.-P. Kriegel, J. Sander, X. Xu, *A Density-Based Algorithm for Discovering Clusters in Large Spatial Databases with Noise In Proceedings of the Second International Conference on Knowledge Discovery and Data Mining*, 1996, pp. 226-231

¹³ J. H. Ward Jr., *Hierarchical Grouping to Optimize an Objective Function In Journal of the American Statistical Association*, 1963, vol. 58, no. 301, pp. 236-244

连接模块还会带来训练上的选择。分阶段学习先训练上游表示，再固定它并训练下游模型；端到端学习根据最终目标共同调整相关参数。例如，压缩模块即使重构误差很小，也可能丢掉对分类有用的微小差别。模块自己的目标是否保留了后续任务需要的信息，需要单独检查。

多个模型也可以共同完成同一项预测，这种做法称为**集成学习** (ensemble learning)。例如，随机森林汇集多棵树的结果，梯度提升逐步加入模型以改善既有预测。此时需要说明各个基模型怎样产生差异，以及它们的输出按什么规则合并。

无论选择单个模型还是组合模型，多维分析都只是明确假设，并不能代替实际比较。最终选择还需要结合数据、任务与资源约束，在相同验证过程下比较预测表现，同时考察存储和查询成本、解释需求，以及面对分布变化时的可靠性。

2.8 本章小结

比较学习权重、建立规则树和保存近邻等模型，需要分别考察参数化方式与表示规模、概率语义、关系形式、输出接口以及损失与学习准则。模型族规定允许作哪些选择，参数或实例表示确定实际使用的关系，学习算法则负责根据数据完成选择。

这五个维度各自回答不同问题。参数化方式与表示规模说明模型表示受到什么限制。概率语义说明是否用分布描述变量，关系形式说明变量如何联系。输出接口说明结果怎样组织以及代表什么。损失与学习准则则说明评价针对逐样本目标、多个对象之间的关系，还是整段轨迹的长期结果。它们需要分开判断，也需要相互配合：线性与非线性结构都能用于概率预测，固定数量的参数也能确定一个分布；类别编号与簇编号虽然形式相同，却需要不同的学习依据。

延伸阅读 模型说明了怎样表示规律，第3章将进一步讨论经验和反馈改变时，怎样组织学习。模型在新数据上是否可靠，还要靠验证与进一步的理论分析。第2部分将讨论有限经验在什么条件下能够支持模型泛化；此后，第三卷“模型”的“经典模型”部分、第三卷“模型”的“神经网络模型”部分和第三卷“模型”的“概率图模型”部分将分别展开经典模型、神经网络模型与概率图模型。

学习范式简介

第 1 章的垃圾邮件分类器从带标签的邮件中学习：模型作出预测，再根据标签检查哪里预测错了。如果只有很少的邮件有标签，甚至一封也没有，学习还能怎样继续？换成下棋或控制机器人时，我们通常无法为每一种处境写出正确动作，只能观察行动的结果。而一个长期使用的系统还会遇到新数据、新任务，以及数据无法集中到一处的限制。

这些问题都与怎样利用经验有关。学习范式涉及系统可以利用什么经验、从哪里获得反馈，以及怎样组织学习。它与任务、模型分别回答不同的问题：任务说明要完成什么，模型说明用什么形式表达规律，范式说明依据什么学习这些规律。表 3.1 用同一个垃圾邮件系统区分这三个层次。

层次	回答的问题	垃圾邮件例子	与其他层次的关系
任务	系统要完成什么？	判断一封邮件是否为垃圾邮件	可以更换模型，任务仍是分类
模型	用什么形式表示输入与输出的关系？	逻辑回归、决策树或神经网络	同一模型可以用于不同学习范式
学习范式	系统利用什么经验和反馈？	从带类别标签的历史邮件学习	可以更换模型，仍是监督学习

表 3.1 任务、模型和学习范式描述机器学习问题的不同层次。它们相互关联，但不存在固定的一一对应关系。

同一个分类任务既可以从完整标签学习，也可以结合少量标签与大量无标签邮件，还可以先从文本中学到有用特征，再用标签学习分类。这里沿用第 1 章的表示概念：用一组特征描述输入。词数、链接数等手工特征是一种表示，模型从文本中学到的特征也可以构成表示。神经网络等模型能够利用不同来源的反馈；深度学习主要涉及模型结构和表示学习方法，文本生成、图像生成描述任务，都不能单独确定学习范式。

本章先用监督学习、无监督学习和强化学习区分三种基本情形：已有目标可供检查、从数据中发现结构，以及通过行动后果学习决策。有了这些基础，就能进一步讨论怎样减少对标签的依赖、提高获取标签的效率，以及数据或任务变化后怎样共享、保留和迁移知识。学习发生的时序与协作环境又会带来额外约束。章末把这些问题放回同一个系统，说明不同范式如何组合。

这些分组按要解决的问题组织，并非彼此互斥的分类。一种方法可以同

时说明反馈从哪里来、知识怎样复用，以及学习在哪里发生；判断一个系统采用了什么范式，需要逐项检查这些条件。

3.1 监督学习

如果已经积累了一批邮件及其类别，我们就有了检查预测的依据：给模型一封邮件，再用已知类别判断它的预测是否合适。这类利用输入及其对应目标来学习预测关系的设定，称为**监督学习**（supervised learning）。学习者从这些配对示例中提取规律，用于预测新输入的目标。

目标的形式取决于任务。垃圾邮件分类的目标是类别，房价回归的目标是成交价格，机器翻译的目标则是与原文对应的译文。目标还可以是次序或其他输出序列，因此监督学习不限于分类和回归。这些任务虽然输出不同，却都能用已有目标检查模型的预测，并据此指导学习。

“监督”并不意味着训练时始终有人站在机器旁边。手写数字的类别通常由人标注，房价预测的目标可以来自成交记录，天气预报的目标可以来自之后实际测得的天气。这些目标来源不同，共同点是每个训练示例都给出了当前任务希望预测的对象。目标只在训练时用于指导学习；面对需要预测的新邮件或新房屋时，模型依靠的是已经学到的关系。

手写数字识别可以让这个过程更具体。MNIST 提供手写数字图像及其类别标签，研究者用它检查模型能否从图像与数字标签的配对中学会识别新笔迹¹。图 3.1 中，训练图像和标签分工不同：图像用于产生预测，标签用于检查预测。使用阶段的新图像则直接交给训练好的模型，由模型判断它写的是哪个数字。

预测与标签的比较怎样变成学习信号？对于一个实际写着“3”的训练图像，即使模型已经把“3”排在最可能的类别中，我们仍可以检查它给这个类别的概率。房价预测则可以比较预测价格与成交价相差多少。损失函数把这些差异转成可计算的量，学习算法据此调整模型，使许多训练样本上的预测更符合目标。具体调整方法可以不同，但都需要把任务要求落实为对预测的评价。

训练样本上的预测改善后，还要检查这种改善能否延续到新样本。为此，需要留出不参与训练和调参的带标签测试样本；测试标签只用于评价，不再反过来指导模型。否则，评价的仍是模型如何适应已经见过的答案，无法据此判断它面对新输入时的表现。

¹ Y. LeCun, L. Bottou, Y. Bengio, P. Haffner, *Gradient-Based Learning Applied to Document Recognition* In *Proceedings of the IEEE*, 1998, vol. 86, no. 11, pp. 2278–2324




图 3.1 监督学习中的训练与使用。训练时图像进入模型，目标标签单独进入损失比较，虚线反馈用于更新参数；使用时只提供新图像。训练行中，数字 3 被暂时预测为 8，原标签 3 只进入比较；使用行没有提供目标。图像卡与内部网络为教学示意，不指定模型架构。

监督学习的效果依赖于目标数据是否可靠、是否覆盖实际使用中的情况，以及训练数据与未来数据是否具有足够相似的规律。若某种笔迹从未出现在训练数据中，或标签本身含有系统性错误，增加训练轮数也不能自动解决问题。带标签数据说明了“希望预测什么”，却不保证有限样本足以代表所有新情况。

3.2 无监督学习

现在去掉逐样本的答案。假设一批新闻没有主题标签，我们仍可以观察哪些词常一起出现、哪些文档内容相近，借助这些规律整理新闻。这类不依赖逐样本目标答案、从数据中发现结构或分布规律的设定，称为**无监督学习**（unsupervised learning）。

要寻找哪一种规律，取决于数据的用途。**聚类**（clustering）把相似样本组织成群组，例如根据购买记录探索顾客的行为模式；**降维**（dimensionality reduction）用更少的变量保留数据中的重要变化或邻近关系，便于可视化、压缩或后续分析；**分布建模**（distribution modeling）描述哪些观测或组合较常出现，可以用于生成样本，或为识别不常见的观测提供依据。没有标签时，这些目标仍然可以用于检查学习结果，只是检查的依据来自数据本身。

以聚类为例，一种思路是反复调整分组，使组内样本在选定的表示下更相似。若只使用顾客的购买金额，分组可能主要反映消费水平；加入购买

时间和商品种类，结果又可能反映购物习惯。同一批顾客可以有不同分组，因为我们选择了不同的表示和相似性标准。“无监督”省去了逐样本的答案，并没有省去学习目标与假设。

回到新闻整理的问题，一篇报道可能既涉及体育，也涉及经济，强行把它放入一个群组会丢掉部分信息。潜在狄利克雷分配（latent Dirichlet allocation, LDA）采用另一种描述：一篇文档可以混合多个主题，每个主题用词语出现的概率来刻画。原始研究曾在 16,000 篇 TREC AP 新闻文档上学习 100 个主题，并观察各主题中概率较高的词²。训练数据没有为每篇新闻预先填写主题标签；学习过程根据词语的共现规律，也就是哪些词经常出现在同一篇文档中，形成主题。研究者随后根据代表性词语解释其含义。图 3.2 展示了从文档集合到主题表示的过程：训练时利用整批文档中的统计规律，使用时则可以据此描述一篇新文档的主题组成。

² D. M. Blei, A. Y. Ng, M. I. Jordan, *Latent Dirichlet Allocation* In *Journal of Machine Learning Research*, 2003, vol. 3, pp. 993–1022




图 3.2 无监督主题发现的过程示意。没有主题标签的新闻集合提供词语共现信息，学习过程形成若干潜在主题；同一篇文档可以由多个主题共同构成，主题名称是在结果解释阶段由人给出的。

主题发现与监督式新闻分类因此有所不同。监督式分类预先规定“体育”“财经”等类别，并用示例标签引导学习；主题发现先寻找词语共同出现的模式，再由人解释结果。即使人最后为某个主题取名为“体育”，这个名字也不是训练时提供的监督标签。一篇报道同时涉及经济和体育，还可以在主题表示中保留多种成分。

从数据中发现的结构，不一定直接对应人关心的概念。例如，把顾客的几十项购买特征压缩成两个数，就可以把每位顾客画成平面上的一个点，观察哪些点聚在一起。但这两个数是降维方法计算出的坐标，横轴和纵轴未必分别对应“收入”“年龄”等容易解释的属性；图上分开的群组，也不一定就是业务上需要区分的顾客类型。

因此，发现结构之后，还需要结合具体用途检查它是否有意义。以新闻主题为例，可以查看一个主题中的代表词和文档是否表达了相近内容，换一批相似新闻重新学习时主要主题是否仍然存在，以及用这些主题整理文档后是否更便于检索。这些检查分别帮助判断结果能否解释、是否稳定，以及是否有实际用途，不能仅凭一张分组清晰的图就认定学习结果有效。

3.3 强化学习

监督学习和无监督学习的例子都从已有数据出发。下棋时，情况更进一步：系统当前选择哪一步，会改变棋盘，也会改变之后需要面对的选择。机器人移动、车辆换道同样如此。我们不仅要判断当前行动是否合适，还要考虑它给后续行动留下了什么处境。

强化学习 (reinforcement learning) 利用行动带来的奖励反馈学习决策，目标通常是提高预期累计回报，即综合多步奖励，并考虑各种可能交互结果的平均表现。作出决策的学习者称为 **智能体** (agent)，与它交互的外部世界称为 **环境** (environment)。例如，下棋程序是智能体，棋局及对手的反应构成它面对的环境；**奖励** (reward) 则是环境提供的数值评价，用来说明某次交互的结果有多好。

智能体需要根据当前可得的信息选择行动。这条选择规则称为 **策略** (policy)。环境的 **状态** (state) 描述当前处境，**观测** (observation) 则是智能体实际拿到的信息。两者未必相同：机器人摄像头只能拍到某个视角，未必能看到所有障碍物。因此，决策有时还要结合先前的观测和行动记录，不能把眼前一帧画面当作完整状态。

奖励与监督标签不同。标签可以直接告诉分类器某张图片是什么，奖励通常只评价行动造成的结果，不会说明当时应当选择哪个动作；奖励还可能延迟出现。例如，下围棋时胜负要等一局结束才能确定，眼前看似有利的落子却可能导致后面输棋。若只按眼前吃子多少来评价，就可能鼓励不利于最终获胜的选择。因此，强化学习需要把当前行动与后续结果联系起来。

记策略为 π ，长度为 T 的交互轨迹为 τ ，第 t 步奖励为 r_t 。策略与环境共同诱导轨迹分布 p_π 。一种常见目标是最大化期望折扣回报

$$j_\gamma(\pi) = \mathbb{E}_{\tau \sim p_\pi} \left[\sum_{t=0}^{T-1} \gamma^t r_t \right], \quad 0 \leq \gamma \leq 1. \quad (3.1)$$

求和先评价一条轨迹，外层期望再按各种可能轨迹出现的概率取平均。参数 γ 称为 **折扣因子** (discount factor)。有限任务取 $\gamma = 1$ 时得到未折扣总回报；取 $\gamma < 1$ 会降低远期奖励的权重，在奖励有界的无限持续过程中也能使折扣和保持有限。折扣因子因而既影响计算，也改变不同时间奖励的

相对权重。

对于长期持续运行的系统，也可以在极限存在时评价单位时间的平均回报：

$$j_{\text{avg}}(\pi) = \lim_{T \rightarrow \infty} \frac{1}{T} \mathbb{E}_{\tau \sim p_{\pi}} \left[\sum_{t=0}^{T-1} r_t \right]. \quad (3.2)$$

折扣回报与平均回报对应不同评价口径；仅比较期望还可能掩盖结果波动，有限交互对长期表现的估计也可能不稳定³。

在边交互边学习的设定中，智能体按当前策略行动，记录观测、动作、奖励与后续观测。学习方法利用这些记录评价长期效果，再调整策略，让可能带来较好回报的行动更容易被选择。策略一变，下一轮遇到的情形也会改变。如果只重复已知有效的行动，可能错过更好的选择；如果不断尝试未知行动，又可能放弃已经能获得的收益。这就是探索与利用之间的权衡⁴。

怎样根据经验改进策略，有几种常见思路。基于价值的方法估计处于某个状态或采取某个行动后能获得的长期回报，再据此选择行动。直接优化策略的方法则直接调整行动规则，以提高预期回报。**行动者—评论家** (actor-critic) 方法结合了两方：行动者选择动作，评论家评估这些选择，为行动规则的更新提供依据。

如果还能够预测环境怎样变化，就可以在真正行动前比较不同选择的后果。为此可以使用已知或从数据中学到的**环境模型** (environment model)，即描述行动如何影响后续状态或观测及奖励的模型，再借助它进行规划。无论采用哪种思路，都需要把眼前反馈与长期结果联系起来。

2015 年的深度 Q 网络 (deep Q-network, DQN) 研究让智能体仅根据 Atari 游戏画面和游戏分数学习控制，在 49 款游戏上使用相同的基本算法与模型设定⁵。智能体看到画面后选择按键，游戏环境更新画面和分数；这些交互不断产生新的经验，智能体据此改善后续行动。图 3.3 用机器人探索场景说明同样的交互分工：行动改变处境，新观测与奖励提供后续学习的依据。深度 Q 网络属于基于价值的方法：它学习估计不同按键在后续游戏中可能带来的累计回报，而不只是预测按下之后立刻增加多少分。这里的游戏分数提供奖励信息，但不会直接给出“此刻应按哪个键”。

在前面的围棋例子中，棋盘局面是状态，落子是行动，胜负在一局结束后提供关键反馈。程序还可以通过自我对弈产生新的棋局，让不同局面的后续胜负为学习提供经验。第 3.7 节将以 AlphaGo 说明这些经验怎样与人类棋谱结合。

在机器人控制中，观测可以来自摄像头、关节位置和力传感器，行动可以是移动关节、调整抓取姿态或选择行走方向，奖励则用于表达是否抓稳物体、是否到达目标以及动作是否平稳。与可以反复重开的游戏不同，真

³ R. S. Sutton, A. G. Barto, *Reinforcement Learning: An Introduction*, MIT Press, 2018, 2nd ed.

⁴ R. S. Sutton, A. G. Barto, *Reinforcement Learning: An Introduction*, MIT Press, 2018, 2nd ed.

⁵ V. Mnih, K. Kavukcuoglu, D. Silver, A. A. Rusu, J. Veness, M. G. Bellemare, A. Graves, M. Riedmiller, A. K. Fidjeland, G. Ostrovski, S. Petersen, C. Beattie, A. Sadik, I. Antonoglou, H. King, D. Kumaran, D. Wierstra, S. Legg, D. Hassabis, *Human-Level Control through Deep Reinforcement Learning* In Nature, 2015, vol. 518, pp. 529–533




图 3.3 机器人探索的概念场景与强化学习的交互分工。上部导航示意展示局部观测、移动与到达目标，不表示测量结果或精确状态转移。下部路径表示策略、环境和学习之间的分工：策略依据历史选择动作，学习利用含奖励的交互记录更新策略；非终止时继续交互。奖励不是正确动作标签，到达目标后的回合终止只属于上部教学场景。

实机器人一次失败就可能损坏设备，经验的获取本身也有成本。

自动驾驶中的路径规划、跟车和换道也可以写成交互决策问题：车辆根据周围交通选择动作，之后的位置、速度和其他车辆反应形成新状态，安全、通行效率与乘坐舒适度共同影响评价。不过，自动驾驶系统包含多个学习问题：环境感知可以采用监督或自监督学习，决策模块则需要考虑行动的后果。类似的序贯决策还出现在推荐、资源调度和能源管理中，是否适合使用强化学习取决于问题需要怎样描述行动的后果、反馈和长期目标。

有些决策问题可以暂时不考虑行动对后续环境状态的影响。例如，推荐一条新闻后，系统只记录这次是否点击，并不建模它对用户后续兴趣的影响。但系统仍然只知道被展示新闻的结果，不知道同一时刻改推其他新闻会怎样。这类只观察所选行动反馈、通过反复选择积累奖励的问题，称为**多臂老虎机问题** (multi-armed bandit)。若选择前还能观察用户特征、候选新闻等信息，就得到**上下文老虎机问题** (contextual bandit)。Li 等人的新闻推荐研究采用了后一设定⁶。

老虎机问题是强化学习中一种简化的决策设定：当前行动不通过改变环境状态影响后续奖励，但它带来的信息仍会影响以后的选择，所以仍需平衡探索与利用。若一次推荐还会改变用户的后续行为，并且这些变化是优化目标的一部分，就需要更完整的序贯决策模型。区别在于对行动后果的建模范围，不能仅凭系统用于推荐就确定设定。

⁶ L. Li, W. Chu, J. Langford, R. E. Schapire, *A Contextual-Bandit Approach to Personalized News Article Recommendation* In Proceedings of the 19th International Conference on World Wide Web, 2010

这些例子带出一个实际问题：如果不能承受反复试错的代价，交互经验从哪里来？可以先在模拟器中学习，或用专家示范提供较可靠的初始行为；也可以采用**离线强化学习**（offline reinforcement learning），在学习阶段利用已经收集的交互记录，而不再额外与环境交互⁷。这些办法可以减少在真实环境中重新试错的次数，但模拟器与真实环境之间仍可能存在差异，历史记录也未必覆盖将来会遇到的状态和动作。因此，学到的策略仍需要经过检验，再逐步用于实际环境。

即使经验足够，奖励也未必完整表达真正的目标。如果只奖励机器人尽快搬完物体，它可能学会快速搬运，却忽略物体是否受损。针对这一问题，可以把任务完成情况、损坏程度等共同纳入评价，对不能接受的行为设置额外约束；对于难以直接写成数值的要求，还可以请人比较不同的行为结果，从偏好反馈中学习评价信号，第 3.7 节会介绍这种组合。无论采用哪种方式，都需要检查实际行为是否符合任务要求，不能只以训练奖励是否提高判断成功。

专家示范还提供了另一种反馈：直接展示在某种处境下应该怎样行动。从这些示范中学习行动方式，称为**模仿学习**（imitation learning）。其中的**行为克隆**（behavior cloning）把专家遇到的观测作为输入、专家动作作为目标，形成一个监督学习问题。

行为克隆的难处在于，学习者的一次失误可能让它进入示范没有覆盖的状态。例如，一步走偏后，后面的观测就不再与原来的路线相同，照搬已有示范可能继续出错。DAgger 等方法因而让学习者在环境中行动，再请专家为它实际遇到的状态提供动作示范，补上原先没有覆盖的情形⁸。模仿学习和强化学习都能处理连续决策，但前者主要从示范学习行动，后者主要根据行动结果的奖励改进策略。仅凭系统会连续行动，还不能确定它采用了哪种范式。

除了直接学习专家动作，还可以尝试从示范中推断行为背后的目标。**逆强化学习**（inverse reinforcement learning）尝试寻找能够解释专家行为的奖励函数，再利用推断出的奖励学习策略⁹。例如，示范路线不仅提供“在此处左转”的动作，还可能帮助推断专家对路程、障碍和安全距离的取舍。不过，同一组行为可能符合多种奖励，有限示范通常不能唯一确定专家的真实目标；从示范学习奖励后，也仍需检验由它引导的行为。

3.4 知识的高效利用

在监督学习中，标签告诉模型需要区分什么，但获取可靠标签往往比收集原始数据更费力。例如，照片可以批量采集，确认每张照片中的物种却可能需要专家。若标注预算有限，就要考虑怎样让已有标签发挥更大作用、利用其余无标签数据，或把新增标注用在更有价值的样本上。

⁷ S. Levine, A. Kumar, G. Tucker, J. Fu, *Offline Reinforcement Learning: Tutorial, Review, and Perspectives on Open Problems* In arXiv preprint arXiv:2005.01643, 2020

⁸ S. Ross, G. Gordon, D. Bagnell, *A Reduction of Imitation Learning and Structured Prediction to No-Regret Online Learning* In Proceedings of the Fourteenth International Conference on Artificial Intelligence and Statistics, 2011, pp. 627–635

⁹ A. Y. Ng, S. Russell, *Algorithms for Inverse Reinforcement Learning* In Proceedings of the 17th International Conference on Machine Learning, 2000

本节围绕这几种办法讨论知识的高效利用。“高效”主要指减少对任务标签的依赖，或提高标签的获取和使用效率，并不意味着计算量一定更小。无标签数据中的结构、已有规则和样本间的关系都可能提供额外依据，但能否帮助目标任务，仍需用可靠的评价来判断。

3.4.1 半监督学习

商品识别中的类别可能已经确定，却来不及给全部图片标注。少量带标签图片可以说明类别含义，其余图片则可能补充不同光照、角度和背景下的样貌。**半监督学习** (semi-supervised learning) 把这两部分数据一起用于目标任务，让标签提供方向，让无标签数据补充对输入规律的认识。

不过，没有答案的图片怎样指导模型？一种办法是利用模型当前已经学到的判断。**自训练** (self-training) 先用有标签数据训练模型，再让它预测无标签样本。其中被采纳为临时训练目标的预测，称为**伪标签** (pseudo-label)。模型用原有标签与选中的伪标签继续学习，之后还可以重新生成伪标签。这里把预测当作临时目标，是为了利用更多数据，并不意味着这些预测已经变成正确答案。

筛选伪标签时，常会参考模型对预测的确定程度，即**置信度** (confidence)。但模型可能很确定地犯错；如果错误伪标签被反复用于训练，原来的误判反而会得到强化。因此，除了筛选，还需要控制伪标签对学习的影响。

另一种办法无需先认定图片属于哪一类，而是检查模型对同一对象的判断是否一致。例如，轻微改变亮度通常不应改变图片中动物的类别。要求这些变换前后的预测保持稳定，称为**一致性约束** (consistency regularization)。同一原图经不同变换得到的版本称为不同**视图** (view)；即使没有类别标签，模型也能比较各视图的预测，把分歧作为调整依据。这个要求依赖变换保留任务含义。若裁剪已经去掉了待识别的动物，再要求类别不变就可能误导学习。

相似样本之间的联系也可以提供线索。**基于图的方法** (graph-based methods) 把样本画成节点，把相似样本连起来，再利用少量已知标签向邻近的无标签节点传播类别信息。经典的图半监督学习用两类样本共同构图，约束相邻节点具有相近预测¹⁰。相关的聚类思路则假设同一密集群组往往属于同一类别。无论怎样组织相似关系，都需要检查它是否与任务有关：如果图片只是因为背景颜色相近而被连在一起，传播的类别就未必可靠。

这些办法也可以共同使用。FixMatch 将伪标签与一致性约束结合：模型对轻微变换后的无标签图片作出预测，若置信度达到要求，就把预测当作临时目标，要求同一图片经过更强变换后仍给出相同判断¹¹。真实标签负责约束类别含义，伪标签和一致性要求则把学习扩展到没有提供标签的图片上。

¹⁰ X. Zhu, Z. Ghahramani, J. Lafferty, *Semi-Supervised Learning Using Gaussian Fields and Harmonic Functions* In Proceedings of the Twentieth International Conference on Machine Learning, 2003, pp. 912–919

¹¹ K. Sohn, D. Berthelot, C.-L. Li, Z. Zhang, N. Carlini, E. D. Cubuk, A. Kurakin, H. Zhang, C. Raffel, *FixMatch: Simplifying Semi-Supervised Learning with Consistency and Confidence* In Advances in Neural Information Processing Systems 33, 2020, pp. 596–608

在包含十类物体图片的 CIFAR-10 实验中，研究者只向模型提供少量训练图片的类别标签，其余训练图片按上述方式参与学习。这里的“无标签”是实验时隐藏了答案，模型不能在训练中查看这些真实类别。图 3.4 展示了两路数据怎样共同形成分类能力。




图 3.4 半监督学习的过程示意。少量带类别标签的图片规定目标，大量无标签图片提供额外结构信息，两路经验共同用于形成分类能力；模型图标内的实心点与空心环分别示意两路学习信号，汇入同一分类器，不表示精确网络结构。无标签图片的隐藏真值不能作为训练答案使用。

在这个例子中，无标签图片仍来自目标任务需要识别的十个类别。如果额外加入大量不属于这些类别的图片，模型也可能自信地把它判断为某个已知类别，再把错误判断用作伪标签。因此，使用额外图片时，需要检查它们是否与目标任务相关，不能只看数量是否增加。

利用无标签数据时，还要明确最终需要预测哪些样本。如果目标是学到一条能够处理以后新样本的规则，就属于**归纳学习**（inductive learning）。若待预测的一批图片已经给定，学习可以利用这些图片本身的结构，目标是为这批特定图片补全答案，则属于**直推学习**（transductive learning），也称转导学习。直推支持向量机就是利用给定待分类样本的例子¹²。

两者区别在于预测范围与学习时可见的输入。半监督描述的是有标签与无标签数据共同参与学习，既可以采用归纳设定，也可以采用直推设定。直推学习允许利用预先给定的待预测输入，但这些样本的真实标签仍需隐藏；它在这批样本上的表现，也不能直接当成对未来新样本的评价。

半监督学习让已有类别标签与无标签图片共同服务于目标任务。若暂时没有这些类别标签，还可以考虑从原始数据中构造另一个有答案的学习问题，先积累可复用的知识。

¹² T. Joachims, *Transductive Inference for Text Classification using Support Vector Machines* In Proceedings of the 16th International Conference on Machine Learning, 1999, pp. 200–209

3.4.2 自监督学习

标注稀缺时，还有一条思路：原始数据能不能同时提供问题和答案？例如，一段完整文本没有情感类别标签，但如果暂时遮住其中一个词，原文就保留着恢复这个词所需的答案。我们无需另请标注者逐句填写，就能构造大量“根据上下文补全内容”的训练示例。

自监督学习（self-supervised learning）就是从数据自身的内容或关系中构造训练目标。除遮挡恢复外，还可以根据前文预测后续内容，或学习匹配同一对象的不同视图。“自”指目标来自数据，并不表示模型自行决定学什么；遮住哪些内容、比较哪些对象，都属于目标设计。设计这些问题，是希望模型为完成预测而学到有用规律：补词可能需要语法与语义，恢复图像区域可能需要纹理、形状及物体关系。模型究竟学到了多少，还要检查它在实际任务中的表现。

BERT 采用的掩码预测展示了怎样构造这类示例¹³。处理文本时，系统先将句子分成 **词元**（token），即模型逐个处理的文本单位，可以是一个字、一个词或词的一部分。训练时随机选取一部分词元，把其中多数替换为表示隐藏内容的特殊标记，即掩码；模型再根据左右上下文预测原词元，原始文本中被遮住的内容就是答案。同一句话因此同时提供输入和目标。例如，在教学句子“猫在垫子上”中暂时隐藏“垫子”对应的词元，输入是保留其余内容的句子，目标是被隐藏的原词元。图 3.5 展示了这个例子中的两路信息：可见内容用于预测，保留的原词用于检查预测是否正确。

¹³ J. Devlin, M.-W. Chang, K. Lee, K. Toutanova, *BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding* In Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, 2019, pp. 4171–4186




图 3.5 掩码预测以“猫在垫子上”为教学例子。输入将“垫子”替换为 [MASK]，原词单独保留为比较目标；模型只能读可见上下文，不能读被保留的答案。括线汇合全部可见词元，珊瑚红虚线将损失反馈到参数；内部网络只作模型图元。

这样得到输入与目标后，就能像监督学习一样比较预测和答案，再调整模型。改用下一词元预测时，输入只保留目标之前的内容，以原文中紧接其后的词元为目标，同样能自动构造大量训练配对。因此，理解自监督学习的关键是追溯目标怎样产生：掩码预测的答案是暂时藏起的原文，监督式情感分类的答案则是另行提供的正面或负面类别。差别在于训练问题的构造方式，不能只用标签是否由人手工填写来判断。

自监督学习与无监督学习有共同动机：利用没有人工任务标签的数据。仍以同一批新闻为例，前面的主题发现直接从词语共现中学习潜在主题；掩码预测则先隐藏部分词元，建立“根据上下文恢复原词”的预测问题。前者主要用学习到的结构描述数据，后者显式地把数据转成可比较预测与目标的训练示例。两者都有学习目标，也都包含人为设定，不能把差别理解为“有没有目标函数”。

在广义用法中，自监督学习可以纳入无监督学习，因为它同样不依赖额外的人工任务标签；在强调训练信号的来源时，人们又常把它单独讨论。本书采用后一种组织方式，以便说明数据怎样被转化为训练目标。

自监督目标可以直接服务于文本生成，也可以先帮助模型学习通用表示，再把这些表示用于分类、问答等具体任务。这种先积累可复用知识的阶段称为**预训练**（pre-training），后续要完成的具体任务称为**下游任务**（downstream task）。例如，先从大量文本中学习词语与上下文的关系，再用少量带情感标签的评论学习区分正面和负面评价。

预训练不会自动给出下游任务的类别含义，最终任务仍可能需要标签或其他说明。自监督学习能否帮助下游任务，取决于构造的目标是否促使模型学到有用规律。例如，若模型只靠相邻词的搭配就能补全被遮住的内容，它未必因此学会理解整段文字。

3.4.3 弱监督学习

从数据自身构造目标是一条途径，利用成本较低但质量较弱的现有标注是另一条途径。要学习定位图像中的汽车，理想的标注应当告诉模型汽车在哪里。但手头也许只有“这张图含有汽车”的说明；从网页收集的图片甚至可能带着错误标签。**弱监督学习**（weakly supervised learning）研究怎样利用这类不够完整、精确或可靠的信号学习，而不是要求所有数据都先达到理想标注标准。

一种有代表性的划分据此区分三种困难：只有部分样本有标签，叫作**监督不完整**（incomplete supervision）；只有整图类别而缺少任务所需的位置等信息，叫作**监督不精确**（inexact supervision）；标签与实际内容不符，叫作**监督不准确**（inaccurate supervision）¹⁴。第 3.4.1 节的半监督学习主要处理监督不完整，因而也属于这一广义弱监督范围。本节重点看粗标

¹⁴ Z.-H. Zhou, *A Brief Introduction to Weakly Supervised Learning* In National Science Review, 2018, vol. 5, no. 1, pp. 44–53

签、错误标签，以及如何从规则中获得监督。

如果标注者能说出一些判断经验，还可以把经验写成规则，让规则为许多样本产生弱标签。Snorkel 支持这种做法：领域专家编写**标注函数** (labeling function)，也就是根据关键词、模式或外部知识给样本一个判断的程序。它可以在依据不足时“弃权”，不作判断。例如，垃圾评论识别可以把“含有链接”作为一条可疑线索，但正常分享也会附带链接，单条规则不一定可靠。Snorkel 综合多条可能一致、冲突或弃权的规则，估计样本属于各类别的概率，再用这些概率标签训练最终模型¹⁵。图 3.6 中的汇合环节，正是把各条规则的判断转成可供模型使用的监督。

用规则提供弱标签可以减少逐条标注的工作，也会把规则的局限带入学习过程。例如，多条规则若都把含链接的评论判为垃圾内容，综合之后仍可能误判正常的分享链接。粗粒度标签也可能遗漏任务需要的信息。因此，评价最终模型时还需要独立的可靠标签；只检查它是否符合原有规则，无法判断它是否学会了真正需要的分类能力。




图 3.6 三条规则在三个未标注评论上的教学投票。正、负、弃分别表示两种倾向与弃票；同一列可能存在冲突。综合规则信号形成训练监督 $\hat{y}_i$ ，图中不规定合并算法，也不把某条规则输出等同于真实标签；评价仍使用独立可靠标签。

回到缺少位置标注的汽车图像，粗标签与细预测之间需要有一条合理的联系。可以把图像看作多个候选区域的集合：既然整图含有汽车，就至少有一个区域应当包含汽车，而不要求每个区域都是汽车。这是**多示例学习** (multiple-instance learning) 的一种典型解释：监督约束的是一组对象，而不是逐一给出组内每个对象的答案。把整图标签直接赋给所有区域，会把背景也错误地当作汽车。

面对带噪声标签 (noisy labels)，常见思路是识别可疑样本、降低其影响，或显式描述标签可能怎样出错，再据此调整学习。例如，可以借助少量经过核验的样本估计标签的可靠性。这里不能把所有难学的样本都视为错标：少见但正确的情形也可能让模型犯错。处理弱监督的核心，是把已

¹⁵ A. Ratner, S. H. Bach, H. Ehrenberg, J. Fries, S. Wu, C. Ré, *Snorkel: Rapid Training Data Creation with Weak Supervision* In Proceedings of the VLDB Endowment, 2017, vol. 11, no. 3, pp. 269–282

知的不确定性纳入学习过程，而不是无条件地把现有标签当作真值。

对于 Snorkel 这类多来源规则监督，通常先估计弱标签来源的可靠性并综合它们的判断，再让最终模型从原始样本及综合后的监督信号中学习。综合过程不能简单地把每一条规则都看成独立的一票；两条仅关键词略有不同的规则可能提供了几乎相同的证据。合理的方法需要考虑来源的准确程度、覆盖范围以及可能的依赖关系，并允许保留不确定性。

这也解释了为什么产生弱标签之后还要训练模型：规则先覆盖一部分典型情形，模型再从原始内容中学习可推广的预测规律，尝试处理规则没有覆盖的新样本。规则提供了起点，但其中的系统性错误也可能被模型继承。弱监督的效果最终要由独立样本上的可靠评价来判断。

3.4.4 对比学习

除了恢复被遮住的内容，数据中已知的对应关系也能提供学习依据。一张照片轻微改变颜色或取景后，我们仍希望模型认出同一个对象。即使没有类别标签，两张图来自同一原图这一关系也已知，可以用来指导表示学习。

对比学习 (contrastive learning) 通过匹配与不匹配的关系学习表示，常见做法是让匹配样本的表示接近，同时让不匹配样本相对分离。希望匹配的一对样本称为**正样本对** (positive pair)，用于对照的一对不匹配样本称为**负样本对** (negative pair)。这里的“正、负”描述样本之间的关系，与二分类中的正类和负类含义不同。

SimCLR 希望先从大量没有提供类别标签的图片中学习视觉表示，再用这些表示完成图像分类。原研究在 ImageNet 等数据上先进行不使用类别标签的表示学习，之后再用带标签数据训练分类器或调整模型，检验这些表示能否帮助识别图像中的对象¹⁶。

SimCLR 把表示学习转化成“找出同一张原图的另一个视图”的问题。每次取一批原始图片，对每张图片分别进行两组随机变换，例如裁剪和颜色变化，得到两个视图；再让同一个模型把各视图转换成可比较的数值表示。对于其中一个视图，来自同一原图的另一个视图是匹配对象，其余原图产生的视图则提供对照。只要求匹配视图接近还不够，因为把所有图片都变成同一个表示也能满足这一点。加入其他图片作对照，才要求模型既保留同一对象在变换下的联系，又保留不同图片之间的区别。

图 3.7 用同一原图的两个变换视图说明这个过程：取景和颜色可以不同，但它们来自同一原图；另一幅猫图的视图作为对照。模型在这一阶段并不知道“鸟”“猫”这些类别，反馈只来自视图是否由同一原图生成，因此这里属于自监督学习。反复比较不同图片后，模型有机会学到不随这些变换轻易改变的视觉特征，再将其用于后续分类。图中的几何位置只表示匹配视图应当接近，不是实验中计算得到的表示分布。

¹⁶ T. Chen, S. Kornblith, M. Norouzi, G. Hinton, *A Simple Framework for Contrastive Learning of Visual Representations* In Proceedings of the 37th International Conference on Machine Learning, 2020, pp. 1597–1607




图 3.7 自监督对比学习的教学示意。同一幅鸟的原图经过保留动物可识别性的裁剪与颜色变化，形成两个视图；它们与另一幅猫图的视图经共享参数的编码器得到表示。实心点与空心圆表示同源匹配，方点表示其他原图的对照；箭头只示意同源拉近与对照相对分离的训练目标。动物图元和表示位置均为教学构造，不是实测影像或表示分布。

匹配关系还可以有别的来源。监督式对比学习用类别标签决定哪些样本应当接近¹⁷。图像与文字也可以配对，例如一张图片和描述它的文字。因此，“对比”说明怎样构造表示学习目标，“自监督”说明监督信号从哪里来；SimCLR 同时符合两种描述，前面的掩码预测则属于不使用对比目标的自监督方法。

这种学习依赖于我们选定的关系。若裁剪已改变图片含义，原本的正样本对就可能不再适合匹配；不同原图也可能拍到了语义相近的对象，把它们全部作为负样本会与后续分类需要发生冲突。使用对比目标时，需要检查这些关系是否保留了目标任务真正关心的信息。

3.4.5 主动学习

对比学习利用已有样本之间的关系。如果还能请人补充标签，但预算有限，就需要决定先标注哪些样本。**主动学习**（active learning）让学习者根据当前知识挑选需要询问的样本，再请人或其他可靠来源给出答案。它希望新增标签能够纠正常见错误，或补足尚未覆盖的情形，使有限预算发挥更大作用。

在常见的样本池设定中，我们有一个未标注样本池、一个当前模型、可以回答查询的标注来源，以及有限的查询预算。选样需要这些资源的支持：

¹⁷ P. Khosla, P. Teterwak, C. Wang, A. Sarna, Y. Tian, P. Isola, A. Maschinot, C. Liu, D. Krishnan, *Supervised Contrastive Learning* In Advances in Neural Information Processing Systems 33, 2020, pp. 18661–18673

若连相关输入都收集不到，或没有可靠的回答来源，仅靠主动选择无法获得缺失的信息。

一项图像主动学习研究从 20 张各数字类别数量均衡的 MNIST 标注图片开始，每轮从未标注池选择 10 张图片获取标签，再重新学习；研究比较了不同选择准则与随机选择¹⁸。基准实验中的“请求标签”是揭示数据集中已经存在但对学习者隐藏的标签，并不表示实验现场真的有标注员实时参与。真实应用可以由医生、工程师或普通标注者提供答案。图 3.8 中的循环体现了主动学习与一次性标注的区别：获得新标签、更新模型之后，下一轮的选择也可以随之改变。

¹⁸ Y. Gal, R. Islam, Z. Ghahramani, *Deep Bayesian Active Learning with Image Data* In Proceedings of the 34th International Conference on Machine Learning, 2017, pp. 1183–1192




图 3.8 池式主动学习的教学示意。蓝色曲线表示当前模型的决策边界，暖色圆圈标出本轮选择的不确定样本。标注者返回标签后，样本并入带标签集合，用于重训模型。下方的点线保留更新前的边界，实线表示更新后的边界；中央带蓝色圈的数字 3 已获标签，右侧带暖色圈的数字 8 是下一轮查询对象。查询预算限制循环。数字图元、二维位置和边界均为教学构造，不表示实测分布或选择收益。

选择哪些样本请求标注，需要考虑这些标签能否帮助模型改进。例如，模型可能对一张严重模糊的数字图片很不确定，但即使获得了它的标签，也未必能学到适用于其他图片的规律；若连续选中许多写法几乎相同的数字，新增标签提供的信息也可能重复。因此，选样时除了看模型有多不确定，还需要考虑样本是否覆盖不同情形，以及标注者能否可靠地给出答案、需要付出多少成本。

主动学习还可以与半监督学习配合。在手写数字识别中，学习者可以挑选部分图片请求真实标签，同时通过伪标签或一致性约束利用其余未标注

图片。前者决定把有限的标注预算用在哪里，后者让没有获得人工标签的图片也能参与学习。

这个查询循环也容易让人联想到强化学习。二者确实都包含选择与反馈，但本例每次询问得到的是所选图片的标签，评价目标是在给定标注预算下提高识别能力；强化学习则用奖励评价行动后果，关注累计回报。我们可以进一步把多轮选样写成序贯决策问题，用强化学习寻找查询策略，但是否这样实现，是主动学习设定之外的另一项选择。

3.4.6 标签利用方式的比较

同样面对标签有限的分类任务，这几种范式利用的资源不同。假设已经收集了一批花卉照片，只有少量照片带有类别标签：半监督学习让已有标签与其余无标签照片共同服务于花卉分类；自监督学习则从照片自身构造训练目标，先学习表示，之后仍需用类别标签或其他信息说明要识别什么。前者直接围绕目标任务利用两类数据，后者着重解决没有额外任务标签时怎样获得学习信号。

若专家只能提供粗略判断，或已有规则能够批量产生不完全可靠的标签，弱监督学习研究怎样利用这些信号并处理其中的错误。若专家可以准确标注部分照片，主动学习则决定优先询问哪些照片。两者分别改变可接受的监督质量和新增标签的获取方式，不能只凭“都节省标注”就混为一谈。

对比学习关注的是怎样使用样本关系：同一照片的不同视图可以提供自监督匹配关系，类别标签也可以决定哪些照片应当接近。因此，自监督说明目标的来源，对比说明目标的构造方式，两者可以重叠；半监督也属于广义弱监督中的监督不完整情形。表 3.2 汇总了这些差别，便于根据可用资源判断哪些办法适用，而不是为一个系统挑选唯一名称。

范式或方法	可以利用的资源	减少标签依赖的方式	需要检查的条件
半监督学习	少量标签与无标签数据	让无标签样本也参与目标任务学习	数据结构与目标类别是否相符
自监督学习	原始内容及其关系	从数据中构造训练目标	所学规律是否对实际任务有用
弱监督学习	粗标签、噪声标签或规则	接受成本较低的不完善监督	标签误差及不同来源的依赖
对比学习	视图、配对关系或类别标签	用匹配关系学习可复用表示	匹配依据是否可靠；也可使用标签
主动学习	可查询的样本与标注来源	优先为有价值的样本获取标签	查询收益、样本覆盖与标注成本

表 3.2 围绕有限标注比较知识的高效利用。减少人工任务标签并不等于减少全部训练成本，也不保证这些方法在任意数据上都能提高效果。

3.5 知识的演进与迁移

标签预算并不是经验利用的全部问题。模型可能先在白天拍摄的道路图像上学习，之后要处理夜间图像；也可能原先只判断物体类别，后来还要估

计距离。已经掌握的知识是否仍然适用，取决于数据和任务分别发生了什么变化，以及新旧能力之间需要保持什么关系。

这里要区分两种变化。数据变化不只是换了几张照片，还可能是拍摄条件、样本组成或输入与目标之间的统计关系改变；从同一分布抽取一批新样本，不等于分布已经改变。任务变化则涉及需要输出什么、区分哪些类别或按什么目标评价，例如从物体识别转为距离估计。相同图像可以服务不同任务，同一任务也可以面对不同的数据分布。

持续学习、多任务学习、迁移学习和元学习从不同角度处理知识的演进与迁移：经验可以沿时间积累，可以在多个任务间共享，可以从来源问题用于目标问题，也可以用来改进后续学习过程。比较时，除了数据与任务是否变化，还要看任务怎样组织、历史数据能否访问，以及最终评价哪些能力。下面从长期积累知识的情形展开。

3.5.1 持续学习

长期运行的系统往往无法一次获得未来所需的全部经验。用户兴趣、拍摄条件会变化，新类别也会不断出现。系统需要适应这些变化，同时保留仍有用的旧能力，这就是**持续学习**（continual learning）。

新旧能力可能依靠同一组参数。只用新数据更新时，旧任务依赖的参数也会改变，旧类别上的表现可能明显下降，这称为**灾难性遗忘**（catastrophic forgetting）。因此，学会新内容后，还必须回头检查旧能力。

以图像识别为例，可以让模型分批接收新类别，并要求它在每个阶段识别截至当时见过的全部类别，预测时不告知图片属于哪个阶段。这种设定称为**类别增量学习**（class-incremental learning）。iCaRL 是处理这一问题的方法，其实验在 CIFAR-100 和 ImageNet 数据上逐步加入类别，同时限制能够保存的旧样本数量¹⁹。图 3.9 展示了这一过程：每个阶段不只考察新类别是否学会，还检查旧类别是否被遗忘。

¹⁹ S.-A. Rebuffi, A. Kolesnikov, G. Sperl, C. H. Lampert, *iCaRL: Incremental Classifier and Representation Learning* In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2017, pp. 5533–5542




图 3.9 持续学习的类别增量过程。不同类别的图像按阶段到来；每个阶段都要学习新增类别，并在截至当前出现过的全部类别上检查能力。三个模型图标沿用相同轮廓与分区，内部逐步保留的填充示意知识积累；分区不对应真实神经元或精确记忆容量。向过去回指的箭头表示对旧知识的保留要求。

讨论持续学习时，需要说明过去的的数据还能保留多少、系统是否会被告知一个新任务已经开始，以及何时检查新旧能力。如果每个阶段都能使用全部历史数据，就可以通过重新训练复习旧内容；如果只能保留少量旧样本，维持旧能力就受到更强的限制。持续学习也不限于新增类别，还可以处理传感器变化、用户兴趣变化或依次出现的新任务。

任务信息是否可见，还会改变问题难度。若陆续学习不同任务，预测时明确告知当前样本应由哪个任务处理，就得到**任务增量学习**(task-incremental learning)；系统可以据此选择相应的输出。若识别目标与输出含义保持不变，数据分布陆续变化，而且预测时不提供任务身份，则是典型的**领域增量学习**(domain-incremental learning)。它与类别增量、任务增量构成持续学习中三种常用的比较设定²⁰。。

例如，白天与夜间图像都要求识别同一组交通标志，可以作为领域增量问题；逐步加入原先没有的标志类别，并要求在全部已见类别中作出判断，则是类别增量问题。如果每次预测都先告知属于哪一组识别任务，系统面对的就更接近任务增量设定。三者都需要按要求保留旧能力，但可用提示和预测范围不同，实验结果不能脱离这些条件比较。若夜间识别改善，却完全失去白天识别能力，就没有满足同时应对两种环境的长期目标。

3.5.2 多任务学习

持续学习受到经验到达顺序与历史数据可访问性的限制。若多个相关任务的数据已经可用，则可以在训练期间共同利用它们。例如，分析街景既要

²⁰ G. M. van de Ven, A. S. Tolias, *Three Scenarios for Continual Learning* In arXiv preprint arXiv:1904.07734, 2019

知道哪里是车辆和道路，也要估计它们有多远，两项任务都可能用到物体边界等信息。**多任务学习**（multi-task learning）让相关任务共享表示或其他知识，共同学习各自的目标。这样，一个任务的反馈可能帮助另一个任务发现需要的特征，减少各任务分别学习相同规律的负担²¹。。这种帮助来自学习过程中的信息共享；只是同时运行多个互不联系的模型，并不能产生这种作用。

具体到街景，逐像素判断道路、车辆或建筑等类别，称为**语义分割**（semantic segmentation）；估计各像素对应物体的距离，称为**深度估计**（depth estimation）。Kendall 等人还将区分不同物体个体的**实例分割**（instance segmentation）纳入联合学习，并研究怎样平衡各任务反馈的影响²²。。

图 3.10 只展示前两项任务：同一图像经过共享的处理部分，再分别产生语义区域和深度预测。两项预测各自与相应标注比较，反馈又共同影响共享部分。因此，一个任务学到的边界信息有机会用于另一个任务，而每项任务仍保有自己的预测要求。

多任务学习不要求任务随时间发生变化。上面的系统可以始终只学习语义分割与深度估计这两个任务，数据也可以预先收集完毕；需要组织的是多个目标之间的知识共享。两个任务可以使用同一批输入及不同标注，也可以拥有各自的数据集，关键在于一个任务的学习能够影响另一个任务。

这与持续学习的区别不能只看“是否有多个任务”。多任务学习通常能够在训练期间反复利用各任务的数据，即使每次更新交替选择一个任务，也仍然可以是联合学习。持续学习则按先后到来的经验更新，旧数据常常无法完整访问，因此还要专门检查旧能力是否被新学习破坏。




图 3.10 多任务学习的过程示意。同一街景及不同任务的标注共同影响共享表示，系统分别输出语义区域和远近关系；两个结果都是概念示意，不是论文实验的实际输出。

²¹ R. Caruana, *Multitask Learning In Machine Learning*, 1997, vol. 28, pp. 41–75

²² A. Kendall, Y. Gal, R. Cipolla, *Multi-Task Learning Using Uncertainty to Weigh Losses for Scene Geometry and Semantics In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 2018, pp. 7482–7491

相关任务可能互相帮助，也可能发生干扰：改善一个任务的参数调整可能损害另一个任务。某一任务数据更多、目标更容易，还可能主导共享表示，使其他任务受损。因此，任务越多并不一定越好，需要分别检查各任务的效果，不能只看一个汇总指标。

3.5.3 迁移学习

共同训练多个任务是一种利用相关性的方式。如果已有模型学过相关问题，现在希望借助这些知识解决一个目标问题，就可以把来源与目标区分开。**迁移学习**（transfer learning）把已有任务或领域中学到的表示、参数等知识用于目标问题，减少需要从头学习的内容。它既可用于标签有限的新任务，也可用于加快学习或适应数据分布变化；关键是来源知识中哪些部分对目标问题仍然有用。

例如，一个模型先从 ImageNet 中的大量通用图片学习图像特征，再利用较少的带标签花卉照片学习区分花卉类别。来源阶段提供边缘、纹理和形状等可复用表示，目标阶段仍需要用花卉任务自己的标签确定哪些差异重要。图 3.11 中，从来源任务通向花卉任务的箭头表示复用已经学到的表示或模型参数：花卉分类从这个基础继续学习，而不必从完全没有图像经验的状态开始。图中的花卉任务是用于说明迁移过程的教学情景。




图 3.11 迁移学习的过程示意。通用图像任务形成可复用的表示，目标任务再用少量花卉标签调整这些知识，最后识别新的花卉照片；来源知识与目标数据共同决定结果。

花卉分类仍需要自己的标签，是因为来源任务不会自动告诉模型哪些差异值得关注。边缘、颜色和纹理可能是识别一般物体与花卉的共同基础，但足以区分汽车和动物的特征，未必足以区分两种外形相近的花。目标标签帮助模型进一步抓住这些细微差异。

图像神经网络的多层处理也体现了这种差别：较早的层常提取边缘、颜色和局部纹理，较后的层再把这些信息组合成与训练任务有关的特征。不同层与来源任务的联系不同，可直接迁移的程度也不同。针对图像网络的研究观察到，较高层的特征通常更依赖原任务，来源与目标越不相似，迁移越受限制²³。这并不意味着高层特征一概不能复用，而是需要结合目标任务决定保留和调整哪些部分。

把已有模型的参数作为起点，再用目标任务数据继续调整，称为**微调** (fine-tuning)。另一种方式是固定已有表示，只学习目标任务所需的输出部分。它们是复用知识的具体办法；选择哪一种，还要考虑目标数据量、来源与目标的差异以及允许调整的范围。

与主动学习相比，迁移学习主要增加的是目标学习者可以利用的先前知识，不必向外界请求新的目标标签。两者可以配合：先迁移通用图像表示，再挑选当前最需要确认的花卉照片请求标注。这种组合能否奏效，既取决于来源知识是否相关，也取决于新增标签是否补足了目标任务的缺口。

迁移不要求任务与数据分布同时变化。前面的通用物体分类转向花卉分类，改变了需要区分的类别；白天训练的物体识别模型用于夜间图像时，类别可以保持不变，改变的主要是输入分布。比较迁移设定时，应说明来源与目标究竟在哪些方面不同，而不是只说模型换了一批数据。

在街景例子中，若先用深度估计学到视觉表示，再将它用于语义分割，最终关注语义分割的改善，就突出了来源任务对目标任务的帮助。若两项监督共同影响共享表示，并分别评价两项任务，则突出了多任务学习。两者可以重叠，迁移也可以借助联合训练实现，不能仅凭训练是否先后判断。与持续学习相比，一次迁移可以只要求目标任务表现良好，不必继续保留来源任务的全部能力。

若复用来源知识反而使目标任务学得更差，就发生了**负迁移** (negative transfer)。判断迁移效果，需要与不采用这些知识时的目标任务表现比较，不能只看来源模型有多大或用了多少数据。

任务不变而数据来源变化时，还需要明确目标数据何时可用。在道路识别中，白天、雨天与夜间的图像可能呈现不同的统计规律。这里用**域** (domain, 也称领域) 描述输入空间及其数据分布，用**源域** (source domain) 指提供已有知识的数据来源，用**目标域** (target domain) 指最终希望模型有效工作的环境。域不能只按数据集名称区分，同一数据集中也可能包含多个环境。

假设模型已从白天道路图像学到识别能力，现在能提前收集一批夜间图像，就可以利用这些目标域数据调整模型。**领域自适应** (domain adaptation, 也称领域适应) 关注借助可获得的目标域数据应对源域与目标域的分

²³ J. Yosinski, J. Clune, Y. Bengio, H. Lipson, *How Transferable Are Features in Deep Neural Networks?* In *Advances in Neural Information Processing Systems* 27, 2014, pp. 3320–3328

标域只提供无标签输入，则是**无监督领域自适应**（unsupervised domain adaptation）。域对抗方法尝试学习较难据以区分数据来自哪个域表示，同时保留源域分类能力，以帮助迁移²⁴。这里的“无监督”限定目标域的标签条件，并不表示整个学习过程没有任何标签；缩小表示差异也不自动保证目标识别正确。

但部署地点可能尚未确定，训练时根本收集不到目标域数据。**领域泛化**（domain generalization）要求仅利用一个或多个源域学习，使模型能够在未见目标域上工作²⁵。例如，只用若干城市的白天和雨天图像准备识别模型，之后直接用于此前没有接触过的夜间道路。这时不能提前根据夜间图像调整表示，也不能假定训练已经覆盖所有将来会遇到的变化。与从同一分布抽取新样本的泛化评价相比，领域泛化还要求应对训练中未见的环境差异。

这一边界同样约束模型选择。本章采用的领域泛化设定不允许用目标域数据选择模型、调整超参数或决定何时停止训练；这些决定需要依靠源域数据，例如留出一个源域来模拟环境变化。Gulrajani 与 Lopez-Paz 的研究专门比较了模型选择方式对领域泛化评价的影响²⁶。目标域数据在这里用于最终检验。模型当然需要读取待预测图像才能输出结果，但读取输入进行预测与利用它更新模型是两回事。

领域泛化可以利用不同源域之间较稳定的特征，例如尝试保留物体形状，减少对某一背景的依赖。但“在源域间稳定”不等于“在所有未来环境中都稳定”，源域数量增加也不必然带来目标域改善。若新环境中的输入或标签规律任意改变，源域经验不足以保证识别成功。领域泛化仍需要来源与目标之间存在可利用的联系，其可学习条件将在第 9.3 节讨论。

部署之后又多了一种可能：虽然训练时见不到夜间图像，系统使用时却能接触这些输入。**测试时适应**（test-time adaptation）允许在测试或部署阶段利用这些数据调整模型参数或统计量。常见设定不提供目标标签；例如，Tent 利用测试输入及模型预测更新部分参数，以降低预测的不确定性²⁷。不过，更有把握不一定意味着更正确，错误预测也可能被更新过程强化。需要说明允许使用哪些测试输入、何时更新，以及不同样本之间是否保留更新结果。

表 3.3 以目标域信息何时可用比较这些设定。若训练阶段按领域泛化准备模型，部署时又继续适应，就同时涉及两个阶段的要求；评价时应明确测试时发生了更新，不能把适应后的结果当成固定模型直接泛化的结果。

²⁴ Y. Ganin, E. Ustinova, H. Ajakan, P. Germain, H. Larochelle, F. Laviolette, M. Marchand, V. Lempitsky, *Domain-Adversarial Training of Neural Networks* In Journal of Machine Learning Research, 2016, vol. 17, no. 59, pp. 1–35

²⁵ K. Muandet, D. Balduzzi, B. Schölkopf, *Domain Generalization via Invariant Feature Representation* In Proceedings of the 30th International Conference on Machine Learning, 2013, pp. 10–18

²⁶ I. Gulrajani, D. Lopez-Paz, *In Search of Lost Domain Generalization* In International Conference on Learning Representations, 2021

²⁷ D. Wang, E. Shelhamer, S. Liu, B. Olshausen, T. Darrell, *Tent: Fully Test-Time Adaptation by Entropy Minimization* In International Conference on Learning Representations, 2021

设定	可用的目标域信息	关键条件
有监督领域自适应	适应时已有目标域带标签样本	用目标监督调整模型，另留样本评价
无监督领域自适应	适应时已有目标域无标签输入	源域标签与目标域输入共同参与学习
领域泛化	训练及模型选择时均无目标域数据	本章标准设定在目标域直接预测，不更新模型
测试时适应	测试或部署时利用目标输入；常见设定无标签	按约定更新参数或统计量，并说明数据与时序限制

表 3.3 目标域数据的可用性区分领域自适应、领域泛化与测试时适应。前两行区分目标监督条件，最后一行强调适应发生的阶段：它们不是完全互斥的分类。

迁移到目标任务时，还需要说明目标一侧能够提供多少带标签示例。前面的花卉分类可以使用较多标注，也可以只给每个新类别几个示例；如果连这几个示例都没有，就需要类别描述等其他信息来表达目标。在这里的分类情景中，**少样本学习**（few-shot learning）指利用极少的带标签示例识别新类别；**零样本学习**（zero-shot learning）则不提供目标类别的带标签训练示例，而借助先前知识及类别描述等辅助信息。两个名称限定的是目标侧的数据条件，并没有规定知识必须怎样获得或迁移。

类别描述怎样变成识别依据？模型需要先学会图像内容与文字含义之间的对应关系。CLIP 是一种同时学习图像和文本表示的方法²⁸。训练数据由图片及其配套描述组成，学习过程让相互匹配的图像与文字表示更接近，并与同批次中不匹配的图文组合区分开。这沿用了第 3.4.4 节的对比思路，只是匹配双方换成了图像与文字。模型积累的不仅是图像特征，还包括哪些文字能够描述哪些视觉内容。

使用时，可以把候选类别写成简短描述，例如“a photo of a cat”（一张猫的照片）和“a photo of a dog”（一张狗的照片），再比较新图像与各段文字的匹配程度，以最匹配的描述确定类别。这个过程不需要再提供该目标分类任务的带标签训练图片，因此是一种零样本分类方式。这里的“零”不表示系统从未学习过任何数据：识别依赖先前的图文学习，也不能保证预训练语料没有包含相关概念。

零样本学习与领域泛化也不能互相替代。前者在这里限制目标类别的带标签训练示例，后者限制目标域数据在训练及模型选择中的使用。一个模型可能对新类别进行零样本分类，却已见过同一拍摄环境的其他图像；也可能在新环境中做领域泛化，而要识别的类别在源域中早已有标签。

3.5.4 元学习

假设系统经常需要识别新的字符，而且每次只能看到几个带标签示例。迁移已有表示可以提供帮助，但我们还可以提前练习这个适应过程：让模型反复面对不同的小任务，检查它从少量示例中学得怎样，再用这些结果改进下一次学习。

²⁸ A. Radford, J. W. Kim, C. Hallacy, A. Ramesh, G. Goh, S. Agarwal, G. Sastry, A. Askell, P. Mishkin, J. Clark, G. Krueger, I. Sutskever, *Learning Transferable Visual Models from Natural Language Supervision* In Proceedings of the 38th International Conference on Machine Learning, 2021, pp. 8748–8763

元学习 (meta-learning) 利用一组任务上的学习经历, 改善后续学习的方式或效果。少样本适应是它的一种用途, 更广义的目标还可以包括学习速度或稳健性²⁹。它常被概括为“学习如何学习”, 意思是从跨任务经验中改进学习过程; 具体系统仍然使用预先规定的模型、目标和更新方式。

要实现这一目标, 一种做法是让模型在许多训练任务上反复经历少样本适应, 再根据适应后的效果改善共同的学习起点。这里的“起点”是模型开始适应某个任务时使用的一组参数。**模型无关元学习** (model-agnostic meta-learning, MAML) 是这种思路的代表: 它根据模型从共同起点进行少量调整后, 在相应任务的新样本上表现得怎样, 来改进这组起始参数³⁰。

MAML 的一组实验使用 Omniglot 手写字符数据集, 每次选少数几个字符类别, 组成一项识别任务。各任务分别从共同起点出发, 用少量带标签字符调整参数, 再用同一任务的另一批样本检查能否识别新的写法。这些适应后的检查结果汇总起来, 用于改进共同起点; 改进后, 再继续练习其他任务。这种跨任务改进学习能力的训练阶段称为**元训练** (meta-training)。

图 3.12 中要区分两种检查。上方各任务的检查样本虽然没有直接用于该任务的少量适应, 却参与了共同起点的学习, 仍属于元训练数据。下方的最终评价使用未参加元训练的新任务; 在上述字符识别实验中, 这意味着新的字符类别。评价考察模型能否从少量新示例中学会新任务。

迁移学习也能把已有参数带到新任务, 为什么还要区分元学习? 可以继续用字符识别来比较。普通的监督预训练把许多旧字符类别合在一起训练, 反馈来自对这些类别的识别误差; 学好后, 再把表示或参数迁移给新的字符任务。MAML 则在准备阶段就把数据组织成许多少样本任务, 每次先适应、再检查, 反馈来自适应之后在该任务新样本上的表现。两个起点即使都使用了大量旧字符数据, 受到的训练要求也不同: 一个以识别来源类别为目标, 另一个直接以少量示例适应后的效果为目标。

在最终使用时, 两者都可能表现为“载入已有参数, 再用少量新数据调整”, 所以需要追溯准备阶段的目标, 才能看清差别。迁移学习关注来源知识如何帮助目标任务, 元学习关注怎样用以往任务改善学习过程; 上面只是用普通监督预训练与 MAML 说明这种差别。两者也有交集, 元学习形成的起点用于新任务, 同样可以视为知识迁移。

少样本问题也不一定要用元学习解决, 普通迁移学习等方法同样可以用于这种数据条件³¹。而元学习能否帮助未来任务, 要看练习任务与未来任务是否相关; 差异过大时, 练习形成的适应方式可能失效。新任务只用几个示例, 并不表示整个系统只学过几条数据, 准备阶段仍可能需要许多历史任务。

少量示例还可以有另一种用法: 把几条评论及其正面或负面标签写进

²⁹ T. M. Hospedales, A. Antoniou, P. Micaelli, A. J. Storkey, *Meta-Learning in Neural Networks: A Survey* In IEEE Transactions on Pattern Analysis and Machine Intelligence, 2022, vol. 44, no. 9, pp. 5149–5169

³⁰ C. Finn, P. Abbeel, S. Levine, *Model-Agnostic Meta-Learning for Fast Adaptation of Deep Networks* In Proceedings of the 34th International Conference on Machine Learning, 2017, pp. 1126–1135

³¹ Y. Wang, Q. Yao, J. T. Kwok, L. M. Ni, *Generalizing from a Few Examples: A Survey on Few-Shot Learning* In ACM Computing Surveys, 2020, vol. 53, no. 3, pp. 1–34




图 3.12 任务内适应与跨任务更新。元训练任务从共同起点 θ 出发，用支持样本得到适应参数 θ'_τ ，再汇总检查损失 L_τ 更新起点；两批样本都参与元训练。元测试的新任务只用支持样本适应，检查评分不回传共同起点。任务与类别名为教学构造，同名卡片代表同一类别的不同记录，不是 Omniglot 原始样本。

语言模型的输入，再接上一条待判断的新评论。模型据此生成答案，在这次使用中不更新参数。这种利用输入上下文中的任务说明或示例作答的方式，称为**上下文学习**（in-context learning）。GPT-3 的少样本实验采用了这样的设定³²。因此，看到“模型用了几个新示例”，还要检查示例是参与参数更新，还是只进入本次输入；仅凭模型能利用输入示例，也无法判断它是否接受过以任务适应为目标的元训练。

元学习与多任务学习都可以使用多个训练任务，但这些任务承担的作用不同。街景系统的多任务学习要做好已有的语义分割与深度估计；上述少样本元学习则利用历史任务练习适应，并在未参与元训练的新任务上评价学习效果。不能仅凭“训练时使用了多个任务”就认定采用了元学习。

3.5.5 数据与任务变化下的比较

表 3.4 汇总了这四种设定。数据与任务是否变化帮助我们定位问题，变化发生的时间、知识服务的对象以及评价要求则进一步区分学习范式。例如，

³² T. B. Brown, B. Mann, N. Ryder, M. Subbiah, J. Kaplan, P. Dhariwal, A. Neelakantan, P. Shyam, G. Sastry, A. Askell, S. Agarwal, A. Herbert-Voss, G. Krueger, T. Henighan, R. Child, A. Ramesh, D. M. Ziegler, J. Wu, C. Winter, C. Hesse, M. Chen, E. Sigler, M. Litwin, S. Gray, B. Chess, J. Clark, C. Berner, S. McCandlish, A. Radford, I. Sutskever, D. Amodei, *Language Models Are Few-Shot Learners* In *Advances in Neural Information Processing Systems* 33, 2020, pp. 1877–1901

多任务学习可以面对固定的一组任务；持续学习可以只面对同一任务的数据分布变化；迁移学习与元学习都可能用于新任务，后者还要追溯过去的训练是否在改进学习过程。

范式	数据怎样变化	任务怎样组织	主要评价要求
持续学习	经验顺序到来，分布可能变化；旧数据访问常受限	任务可以不变，也可增加类别或依次出现新任务	学习新内容，同时保留所需旧能力
多任务学习	各任务可共享输入，也可使用不同数据集；不要求随时间变化	一组相关任务共同学习，任务集合可以固定	分别检查各任务表现与共享带来的影响
迁移学习	来源与目标的分布可以不同	区分来源与目标；目标任务可相同或不同	来源知识是否帮助目标任务
元学习	用训练任务积累学习经验，再以新任务数据考察适应	跨任务改进学习过程；本节以少样本适应为例	在给定适应数据和预算下学得怎样

表 3.4 从数据、任务及评价要求比较知识的演进与迁移。各行描述本节的典型设定，不是由“变或不变”唯一确定的互斥类别。

仍以道路图像为例，白天识别模型转向夜间图像，若只考察来源知识能否改善夜间识别，重点就是迁移；若系统随时接触不同环境，并要求继续保持已学会的白天识别能力，就还要考察持续学习。若同一系统共同学习物体识别与距离估计，任务集合即使保持固定，也可以采用多任务学习。若利用多个历史场景反复练习从少量示例适应，再在新场景中检查适应效果，则体现了本节所述的元学习思路。区别落在知识怎样组织和怎样评价，不能只看是否出现新数据或多个任务。

即使都归入跨域迁移，仍须进一步检查目标信息：提前利用夜间数据对应领域自适应；训练与选择模型时完全见不到夜间数据、随后直接预测，对应领域泛化；部署后利用夜间输入继续更新，则涉及测试时适应。数据和任务是否变化之外，何时能访问哪些信息也是区分设定的必要条件。

这些关系也说明，知识既可以跨任务共享，也可以沿时间积累。一组任务共同学到的表示可以成为之后迁移的起点，元学习形成的适应方式也可以用于持续到来的任务。能否组合，不仅取决于任务是否相关，还取决于当前能否访问所需数据，以及评价是否覆盖真正要保留和获得的能力。

3.6 其他范式

即使反馈来源和任务目标已经确定，学习仍可能受到发生方式与环境的约束。数据可能逐条到来，要求模型不断预测和更新；也可能分散在不同设备上，只能通过协作利用。这些条件分别涉及学习的时序，以及数据的存放与协作方式。本节将在线学习与联邦学习归为其他范式，它们可以与前面的学习设定组合。

3.6.1 在线学习

如果预测请求和反馈持续到来，等到所有数据收齐再训练就不合适了。**在线学习**（online learning）让学习者在经验依次到来的过程中作出预测或决策，并利用随后获得的反馈更新。它的典型过程是用当前模型预测，取得反馈后调整，再处理后续样本；与之相对，**批量学习**（batch learning）先利用一批给定数据训练，再使用得到的模型。

广告点击率预测提供了一个实际例子：系统根据广告内容和展示场景预测点击，之后观察用户是否点击，用不断到来的反馈更新模型³³。这里点击结果提供监督目标，“在线”则说明这些反馈按什么时序参与学习。反馈可能延迟到达，更新也可以按小批次进行；在线学习既不要求必须联网，也不意味着部署一个提供实时预测的模型就已经在在线学习。若模型始终不利用新反馈更新，它只是持续提供预测。

在线学习与持续学习会重叠，但关注点不同。即使新样本始终来自同一分布，也可以依次预测和更新；在线学习本身不以任务变化或保留一组旧任务为必要条件。持续学习强调长期适应与能力保留，也可以按阶段接收一批数据再更新。一个逐条学习新反馈、同时检查旧能力的系统，则同时具有这两种特征。

数据按时间到来时，还可能发生**概念漂移**（concept drift），即产生数据的统计规律随时间改变。例如，同样的广告和用户特征，过去容易带来点击，现在却不再有效；也可能是常见用户或广告类型的比例改变。前一种变化影响给定输入后的目标规律，后一种改变输入分布。这类变化可能使旧经验不再充分代表当前情况，需要检测变化或调整不同时间经验的权重³⁴。在线更新提供了利用新经验的时序安排，但不会自动消除漂移的影响；它还要应对反馈延迟与新样本不足。第9.1.2节将进一步区分分布中哪些部分发生变化，而这里强调这些变化沿时间出现。

评价在线学习时，应按实际可用信息的时间顺序记录预测：先保存模型尚未见到答案时的结果，再在反馈到达后更新。若用已经参与更新的样本重新预测，就无法反映系统当时面对新数据的表现。还需要说明反馈延迟、允许保留的数据量和更新预算，因为这些条件决定了模型何时能够利用经验。

3.6.2 联邦学习

手机键盘要预测用户接下来会输入什么，需要学习多样的用词和表达方式。每台手机只有一部分输入记录，其他手机虽有相关数据，却不便把原始文本都集中到一处。这里缺少的未必是全局数据量，而是一种共同利用分散数据的办法。

³³ H. B. McMahan, G. Holt, D. Sculley, M. Young, D. Ebner, J. Grady, L. Nie, T. Phillips, E. Davydov, D. Golovin, S. Chikkerur, D. Liu, M. Wattenberg, A. M. Hrafnkelsson, T. Boulos, J. Kubica, *Ad Click Prediction: A View from the Trenches* In Proceedings of the 19th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 2013, pp. 1222–1230

³⁴ A. Bifet, R. Gavaldà, *Learning from Time-Changing Data with Adaptive Windowing* In Proceedings of the 2007 SIAM International Conference on Data Mining, 2007, pp. 443–448




图 3.13 中心协调式联邦学习的一轮通信。协调方向三个示意参与方下发同一组共享参数 $\theta^{(t)}$ ；各方使用边界内的本地记录 D_i 学习，上传本地模型更新。加权聚合形成下一版本 $\theta^{(t+1)}$ ，再统一下发。记录图元与参与方数量为教学示意；原始记录留在本地，但模型更新仍可能泄露信息，联邦组织方式本身不提供隐私保证。

联邦学习（federated learning）让不同设备或机构保留本地数据，通过交换模型更新等信息协作学习。手机键盘的相关研究就在设备端训练下一词预测模型，再汇总各设备的学习结果以改善预测³⁵。下一词目标来自文本本身，本地可以采用自监督学习；联邦学习则回答这些本地经验怎样共同参与训练。两者描述同一过程的不同方面。

一种常见的中心协调过程是：服务器向一批设备发送当前模型，设备用本地数据继续学习，再把学到的模型变化发送给服务器。这里交换的“模型更新”可以是模型参数或参数的改变量，服务器将各方结果汇总，形成下一轮使用的共享模型。**联邦平均**（federated averaging, FedAvg）就是这种组织方式的代表方法，它通过加权平均各设备训练后的模型参数来形成共享模型³⁶。图 3.13 展示了模型下发、本地学习和更新汇总的循环。

这个循环要面对实际设备的差异：有的设备数据多，有的设备算力弱，还可能有设备中途离线。模型反复下发和上传也需要通信成本。原始数据虽然留在本地，模型更新仍可能透露本地信息，所以隐私保护还需要额外措施，例如限制谁能访问单个设备的更新。协作训练中的模型聚合、通信与部署问题由第六卷“系统”的“机器学习系统”部分展开，隐私保护方法则在第3部分“机器学习可信性”中讨论。

³⁵ A. Hard, K. Rao, R. Mathews, S. Ramaswamy, F. Beaufays, S. Augenstein, H. Eichner, C. Kiddon, D. Ramage, *Federated Learning for Mobile Keyboard Prediction* In arXiv preprint arXiv:1811.03604, 2018

³⁶ H. B. McMahan, E. Moore, D. Ramage, S. Hampson, B. Agüera y Arcas, *Communication-Efficient Learning of Deep Networks from Decentralized Data* In Proceedings of the 20th International Conference on Artificial Intelligence and Statistics, 2017, pp. 1273–1282

联邦学习可以缓解单个参与方的数据不足，但不同用户的用词习惯仍可能不同。它可以与迁移学习结合，让某台设备在共享模型的基础上适应本地数据；也可以采用多任务学习，让不同参与方的任务共享信息，同时保留各自的差异。若用户习惯又随时间变化，还会出现持续学习问题。因此，协作利用分散数据、适应各方差异和保留旧能力，可能是同一个系统需要同时解决的问题。

3.7 范式的组合

前面的范式分别约束反馈来源、标签利用、知识复用和学习环境。同一个系统可能同时面对几类问题，因此可以在不同阶段采用不同范式，也可以在同一阶段利用多种信号。理解组合时，要分别追踪各阶段的数据、目标与反馈，并说明哪些知识被传给下一阶段。

预训练与下游学习是一种常见组合。模型先在大量无标签文本上用自监督目标学习表示，再用带任务标签的数据进行监督学习。前一阶段提供可复用的知识，后一阶段把它调整到问答、分类或其他具体任务。半监督学习则在同一目标任务中共同使用有标签和无标签数据，有些方法还会附加自监督目标。两者都包含多种信号，但组织方式和问题设定并不相同。

2016 年的 AlphaGo 提供了棋谱与胜负反馈结合的实例。它先让负责选择落子的策略网络从专家棋谱中的局面与落子学习，得到初始策略，再通过自我对弈，根据最终胜负继续改进策略³⁷。从棋谱到自我对弈，传递的是已经学到的模型；后续反馈则从专家动作变为对局结果。图 3.14 只呈现这条学习主线，完整系统还包含搜索等组件。这里的自我对弈属于强化学习过程，不能因名称中有“自我”就归为自监督学习。

³⁷ D. Silver, A. Huang, C. J. Maddison, A. Guez, L. Sifre, G. van den Driessche, J. Schrittwieser, I. Antonoglou, V. Panneershelvam, M. Lanctot, S. Dieleman, D. Grewe, J. Nham, N. Kalchbrenner, I. Sutskever, T. Lillicrap, M. Leach, K. Kavukcuoglu, T. Graepel, D. Hassabis, *Mastering the Game of Go with Deep Neural Networks and Tree Search* In Nature, 2016, vol. 529, pp. 484–489




图 3.14 AlphaGo 学习主线的简化示意。人类棋谱为监督学习阶段提供局面与专家落子；得到初始策略后，自我对弈产生新棋局与胜负反馈，用于强化学习阶段。完整系统还包含搜索等组件。

还有些行为难以直接打分，却比较容易比较好坏。例如，我们未必能为机器人的每一步动作写出奖励，但可以比较两段行为哪一段更符合要求。

偏好学习（preference learning）利用的就是这类相对判断。它与强化学习的一种组合方式是向人展示两段行为，请人选出更满意的一段，用比较结果训练一个评价模型，再用该模型提供的奖励训练智能体。相关研究曾将这种方法用于 Atari 游戏和模拟机器人任务³⁸。这里，人提供的是“哪段行为更好”的比较，而不是每一步该怎么做的动作示范；评价模型把这种偏好转成奖励，强化学习再利用奖励改进行动。

组合也可以发生在同一个训练过程中。以一个假设的花卉识别系统为例：不同机构各自保留照片，通过联邦学习协作训练；各机构从本地无标签照片构造不同视图，利用自监督对比目标学习表示。其中，联邦学习规定数据怎样分布与协作，自监督学习说明匹配信号从哪里来，对比学习说明怎样利用这些关系形成目标。三种描述各有作用，并不相互替代。

若还能够请专家标注部分照片，系统可以主动选择需要询问的样本，再结合其余无标签照片进行半监督学习。已有通用图像表示可以迁移到花卉识别；随着新物种陆续加入，系统又需要检查持续学习中的旧类别保留。这是为说明组合而构造的教学情景，实际方案只需采用问题所要求的部分。标签选择不能代替目标任务的学习，协作训练也不会自动解决来源差异或遗忘。

³⁸ P. F. Christiano, J. Leike, T. B. Brown, M. Martic, S. Legg, D. Amodei, *Deep Reinforcement Learning from Human Preferences* In *Advances in Neural Information Processing Systems 30*, 2017, pp. 4299–4307

3.8 本章小结

学习不必依赖完整标签；关键是先确定系统能从数据、交互或已有任务中获得什么反馈，再用相应范式组织训练和评价。任务、模型与学习范式分别说明要完成什么、怎样表示规律，以及依据什么经验学习这些规律。监督学习利用输入及对应目标，无监督学习从数据中发现结构或分布规律，强化学习则根据行动带来的奖励改进决策。判断反馈的来源，比模型采用什么名称更能说明学习是怎样发生的。

回到章首的标签不足问题，学习可以利用未标注数据补充已有监督，从数据自身构造目标，接受较弱但成本较低的监督，或主动获取关键标签。对比学习进一步说明怎样用样本关系形成表示学习目标。这些办法能否发挥作用，取决于额外信号是否可靠、是否与目标任务有关；减少人工标签并不保证模型自动获得所需能力。

数据或任务变化后，还要明确知识服务的对象与需要保留的能力。持续学习考察顺序更新中的适应与保留，多任务学习考察相关任务间的共享，迁移学习考察来源知识对目标问题的帮助，元学习则用历史任务改进后续学习过程。在线学习与联邦学习进一步限定更新时序和协作环境。目标域信息何时可用，又区分了领域自适应、领域泛化与测试时适应。这些维度可以组合，因此分析一个系统时，应分别说明数据、反馈、任务关系和信息可用条件，并按最终需要获得或保留的能力评价结果。

延伸阅读 若要深入理解交互决策，可从 Sutton 与 Barto 的强化学习教材继续；若关注标签质量和任务适应，可分别阅读弱监督学习综述与元学习综述；联邦平均的原始研究则提供了分散数据协作训练的具体入口³⁹。结合第 2 章，我们已经能分别说明怎样表示规律，以及怎样利用经验学习这些规律。第 2 部分将进一步讨论有限经验在什么条件下能够支持泛化。第四卷“范式”将围绕强化学习、知识的高效利用、知识的演进与迁移展开具体方法，协作训练与部署约束则衔接系统卷。

³⁹ R. S. Sutton, A. G. Barto, *Reinforcement Learning: An Introduction*, MIT Press, 2018, 2nd ed. Z.-H. Zhou, *A Brief Introduction to Weakly Supervised Learning* In National Science Review, 2018, vol. 5, no. 1, pp. 44–53; T. M. Hospedales, A. Antoniou, P. Micaelli, A. J. Storkey, *Meta-Learning in Neural Networks: A Survey* In IEEE Transactions on Pattern Analysis and Machine Intelligence, 2022, vol. 44, no. 9, pp. 5149–5169; H. B. McMahan, E. Moore, D. Ramage, S. Hampson, B. Agüera y Arcas, *Communication-Efficient Learning of Deep Networks from Decentralized Data* In Proceedings of the 20th International Conference on Artificial Intelligence and Statistics, 2017, pp. 1273–1282

第二部分

机器学习理论

Machine Learning Theory

统计学习框架

一个垃圾邮件分类器在已经标注的邮件上很少出错，并不意味着它在明天收到的邮件上也会表现良好。它可能学到了能够推广的假设，也可能只是记住了训练邮件。两种做法在训练集上都能得到很高的准确率，但我们真正关心的是它们对新邮件的判断。

检验一组没有参与训练的邮件，可以帮助评价当前分类器。不过，一次测试仍没有回答学习算法是否可靠：如果换一批训练邮件，算法还能得到同样好的分类器吗？统计学习理论研究的正是这种从有限样本推断未来表现的依据。为此，需要区分训练数据、算法选出的分类器以及未来邮件的来源，并把“表现好”和“训练可靠”分别写成可以分析的条件。

本章从一个学习问题必须规定的对象出发，建立第 4–9 章共用的框架。垃圾邮件二分类将这些抽象对象具体化，PAC 标准说明怎样评价训练是否可靠；学习的限制与模型选择则解释何时不能仅凭经验风险作出可靠判断，以及怎样权衡表达能力与统计代价。

4.1 学习问题

同一句“算法从样本中学到一个模型”，可以对应不同的观测单位、候选对象、评价标准和概率来源。若这些要素没有写明，两个形式相似的风险界也可能回答不同问题。本节建立第 4–9 章共用的学习问题设定：它说明学习问题必须交代哪些对象，但不预先规定这些对象只能取分类问题中的形式。

定义 4.1 学习问题的形式设定 一个学习问题至少需要规定观测空间 Z 、比较决策空间 $\mathcal{W}$ 、算法输出空间 $\mathcal{W}_{\text{out}}$ 、损失函数、允许的数据来源和抽样机制。

在 Z 与 $\mathcal{W}^+ = \mathcal{W} \cup \mathcal{W}_{\text{out}}$ 上约定相应的可测结构，并要求损失

$$\ell : \mathcal{W}^+ \times Z \rightarrow \mathbb{R}$$

联合可测。

在本章采用的标准同分布基线中，允许的数据来源组成分布族 $\mathfrak{P}$ 。给定 $\mathcal{P} \in \mathfrak{P}$ ，训练样本写作 $S = (z_1, \dots, z_n) \sim \mathcal{P}^n$ 。

内部随机数 U 定义在另一个概率空间并独立于 S 。学习算法 A 是从这些输入到 $\mathcal{W}_{\text{out}}$ 的可测映射，输出 $A(S, U)$ ；确定性算法省略 U 。

观测空间 Z 规定一条观测包含什么，损失 ℓ 则用这条观测评价一个决策。比较空间 $\mathcal{W}$ 规定学习结果与哪些候选决策比较，输出空间 $\mathcal{W}_{\text{out}}$ 规定算法实际上可以交付什么；二者不必相同。

分布族 $\mathfrak{P}$ 规定一个结论声称覆盖哪些数据来源，而不是算法可以从样本中直接读出的附加信息。抽样机制说明训练观测之间以及训练数据与评价数据之间的关系；独立随机数 U 则单独表示算法内部的随机性。算法 A 把可见样本和内部随机数映射为输出空间中的决策。

各章共享的是上述对象及其职责，不是同一个抽样公式。二分类、多分类和本章后续内容采用训练与评价同分布的基线；迁移学习会分别指定源域与目标域、多个样本量或环境层抽样，并相应改变评价风险和概率来源。因而，式 $S \sim \mathcal{P}^n$ 不能在数据关系改变后原样沿用。

调用这套设定时，观测与抽样单位以及训练样本的联合分布必须明确。单条记录、序列和环境块对应不同的独立性条件与样本量；允许分布族又决定结论覆盖哪些数据来源，因此分布无关、受限分布和跨域结论具有不同范围。

决策或假设空间、损失与比较基准也须配套给出。最佳风险、近似误差和容量都相对于比较空间定义，“误差小”则要区分绝对风险与超额风险。算法接口还应说明哪些数据和辅助信息可见，以及结果属于 $\mathcal{W}_{\text{out}}$ 中的哪类对象。若算法输出始终属于比较空间，就是恰当学习；允许输出比较空间之外的决策，则可能改变可学习性和计算难度。

概率来源和保证类型不能混用：新观测、训练样本、算法随机数和环境抽样对应不同的随机性，期望保证、高概率保证与逐环境保证也不能互换。可测性与可分性条件保证概率、期望和经验过程上确界有定义；统计、可计算和高效要求则分别关心样本量、程序能否停机，以及训练和预测所需的时间资源。二分类、多分类、一般实值损失和跨域学习都可以用这些对象表述；其中任何对象发生变化，都可能改变保证的含义，局部定理还需补充有界性、凸性或覆盖等条件。

式 (1.4) 和 (1.16) 分别在带标签预测中给出了经验风险与期望风险。把参数化预测器换成一般决策 w ，把输入标签对换成一般观测 z ，就能为分类器、回归函数、聚类中心及其他决策提供统一记号；风险的具体含义仍由观测和损失决定。

定义 4.2 一般学习问题的期望风险 设 $\mathcal{P} \in \mathfrak{P}$ 。对任意 $w \in \mathcal{W}^+$ ，若 $\ell(w, \cdot)$ 在 $\mathcal{P}$ 下可积，则 w 的期望风险为

$$R_{\mathcal{P}}(w) = \mathbb{E}_{z \sim \mathcal{P}} \ell(w, z).$$

定义 4.3 一般学习问题的经验风险 给定样本 $S = (z_1, \dots, z_n) \in Z^n$ ，任意 $w \in \mathcal{W} \cup \mathcal{W}_{\text{out}}$ 的经验风险为

$$\hat{R}_S(w) = \frac{1}{n} \sum_{i=1}^n \ell(w, z_i). \quad (4.1)$$

在标准同分布基线中，这里采用允许类内最低风险非零的超额风险形式：以 $\mathcal{W}$ 中的最低期望风险为比较基准，并对允许分布族统一控制训练失败的概率。

调用下面的定义时，默认 $\inf_{w \in \mathcal{W}} R_{\mathcal{P}}(w)$ 有限，随机输出的期望风险几乎处处有限，且 $R_{\mathcal{P}}(A(S, U))$ 作为 (S, U) 的函数可测。具体无界损失还须在相应定理中给出保证这些条件成立的可积性或矩条件。PAC 先回答统计上是否能学到，再由计算接口补充学习过程能否实现。

定义 4.4 相对于分布族的 PAC 可学习性 若存在算法 A ，对任意 $\varepsilon, \delta \in (0, 1)$ 存在整数 $n_0(\varepsilon, \delta)$ ，使任意 $\mathcal{P} \in \mathfrak{P}$ 和 $n \geq n_0(\varepsilon, \delta)$ 均满足

$$\mathbb{P}_{S \sim \mathcal{P}^n, U} \left\{ R_{\mathcal{P}}(A(S, U)) \leq \inf_{w \in \mathcal{W}} R_{\mathcal{P}}(w) + \varepsilon \right\} \geq 1 - \delta,$$

则称该学习问题相对于 $\mathfrak{P}$ 是 PAC 可学习的。概率包含训练样本和算法内部随机数；确定性算法省略 U 。只有当 $\mathfrak{P}$ 包含所讨论空间上的全部相关分布时，才称这一保证为分布无关。

若算法始终输出 $\mathcal{W}$ 中的决策，就称为**恰当学习** (proper learning)；允许输出 $\mathcal{W}$ 之外、但属于 $\mathcal{W}_{\text{out}}$ 的决策，则称为**非恰当学习** (improper learning)。两种算法使用同一个比较基准 $\inf_{w \in \mathcal{W}} R_{\mathcal{P}}(w)$ ，区别只在允许输出的范围。

可测性与可分性约定 本部分约定：对出现在上确界中的一致有界损失函数类 $\mathcal{F}$ ，每个 $f \in \mathcal{F}$ 均可测，并存在可数子类 $\mathcal{F}_0$ ，使每个 $f \in \mathcal{F}$ 都能由 $\mathcal{F}_0$ 中的一列函数逐点收敛得到。涉及学习器、压缩、重构或其他数据依赖输出时，还要求相应映射可测。

这个充分条件使有限样本上的上确界可以化为可数上确界；由有界收敛，期望风险的相应上确界也可作同样替换。需要经验风险最小化的存在性证明时，可以在固定枚举的可数子类中选择第一个达到给定容差的决

策，从而得到可测的近似 ERM。若具体问题不能建立这种可数逼近或可测选择，就需要改用外概率表述，或另外给出适用的经验过程条件。无界损失还必须在相应定理中单独检查可积性和所需矩条件。

定义 4.4 只规定统计保证。若进一步要求学习程序在给定编码下停机，且输出的预测程序对每个允许输入都停机，就进入**可计算学习** (computable learning)；若还要求样本量、训练时间和预测时间具有规定参数的多项式上界，就进入**高效学习** (efficient learning)。这三层要求不能相互代替，第 4.3.3 节将用二分类问题给出具体定义。

4.2 二分类问题

下面把第 4.1 节的一般设定特化到二分类：取 $Z = X \times Y$ 、 $Y = \{0, 1\}$ 、 $\mathcal{W} = \mathcal{H}$ ，暂令 $\mathcal{W}_{\text{out}} = \mathcal{H}$ ，并令 $\ell(h, (x, y)) = \ell_{01}(h(x), y)$ ，即用零一损失评价预测。这样可以沿用垃圾邮件例子建立直觉，再逐步说明可实现与不可知两种 PAC 比较基准。

学习算法根据已经知道类别的邮件，选择一个用来判断新邮件的假设。即使训练数据中的每个标签都正确，这些数据也可能不足以确定应该采用哪个假设。

例如，假设我们已经为每封邮件计算了一个介于 0 和 1 之间的可疑程度分数。分数越高，只表示邮件越具有被评分程序视为可疑的特征；它不一定等于邮件是垃圾邮件的概率。为了集中讨论如何从数据选择假设，暂时把评分程序看成固定的，只调整分类时使用的分界值。分类器把分数达到分界值的邮件判为垃圾邮件，把低于分界值的邮件判为正常邮件。这个分界值称为**阈值** (threshold)。

考虑一份人为构造的训练集，其中只有四封邮件。分数为 0.1 和 0.3 的两封邮件已被人工标为正常邮件，分数为 0.7 和 0.9 的两封邮件已被标为垃圾邮件。阈值取 0.4 时，前两封邮件的分数低于阈值，后两封高于阈值，四封都能分对。阈值取 0.6 时，四封邮件的预测结果也完全相同。训练集在 0.3 与 0.7 之间没有提供邮件，所以这两个假设都符合已经观察到的标签。

现在收到一封分数为 0.5、尚未标注的新邮件。阈值为 0.4 的假设会把它判为垃圾邮件，因为 $0.5 \geq 0.4$ ；阈值为 0.6 的假设会把它判为正常邮件，因为 $0.5 < 0.6$ 。表 4.1 列出了这次比较。我们还不知道新邮件的真实类别，因此不能断定哪个假设正确；能够确定的是，原来的四封训练邮件不足以区分这两个假设。

邮件分数	已知类别	阈值 0.4 的预测	阈值 0.6 的预测
0.1	正常	正常	正常
0.3	正常	正常	正常
0.7	垃圾	垃圾	垃圾
0.9	垃圾	垃圾	垃圾
0.5	尚未标注	垃圾	正常

表 4.1 两个阈值假设对同一组邮件的判断。前四行是人为构造的训练数据，最后一行是待预测的新邮件。两个假设在训练集上都正确，却对新邮件给出不同类别。

4.2.1 数据与假设

一封邮件提供给分类器的信息称为**输入**，人工给出的真实类别称为**标签**。在这个例子中，输入是邮件分数，记为 x ；标签记为 y ，约定 $y = 1$ 表示垃圾邮件， $y = 0$ 表示正常邮件。输入空间 X 收集所有允许的输入，标签空间 Y 收集所有允许的类别。这里 $X = [0, 1]$ 、 $Y = \{0, 1\}$ ；实际模型的输入也可以是多个特征组成的向量，而不只是一项分数。

一条确定的分类规则称为一个**假设** (hypothesis)。它规定每个允许输入应该被预测成哪一类，因此可以写成函数 $h : X \rightarrow Y$ 。例如， $h(0.5) = 1$ 表示这个假设会把分数为 0.5 的邮件判成垃圾邮件，并不表示这封邮件的真实类别已经被观察到。

假设空间 (hypothesis class) 是学习算法允许选择的假设的集合，记为非空集合 $\mathcal{H}$ 。如果只允许调整阈值，那么每个阈值对应一个假设，全部阈值假设构成阈值假设空间：

$$\mathcal{H}_{\text{thr}} = \{h_t : t \in [0, 1]\}, \quad h_t(x) = \begin{cases} 1, & x \geq t, \\ 0, & x < t. \end{cases} \quad (4.2)$$

下标 t 用来区分不同假设。前面的两个阈值假设分别是 $h_{0.4}$ 和 $h_{0.6}$ 。学习算法要决定的是选哪个 t ，选定以后才用相应的 h_t 预测新邮件。

只考虑基于阈值的假设，已经加入了一项限制：较高分数的邮件不会在越过阈值后被判为正常邮件。训练数据本身没有强迫我们采用这个限制。例如，一个只记住四封邮件但对其他邮件随意分类的假设，也可能在这四封邮件上全部正确。预先限制假设空间或规定假设的选择偏好，称为**归纳偏置** (inductive bias)。它使算法在样本没有直接给出答案的地方，仍能按照某种确定的原则作出判断。

奥卡姆剃刀常被用来表达优先选择简单解释的思想。在这里，“简单”必须落实到具体假设：一个阈值只需确定一个分界值，逐条记忆则需要保存每个训练输入。但描述长短依赖采用的编码，不能脱离表示方式，把“简单”本身当成泛化定理。学习理论还要证明所采用的限制为什么有效。

4.2.2 损失、期望风险与经验风险

比较假设之前，需要约定怎样计算一次预测的错误。**损失** (loss) 给每次预测赋予一个代价。对于当前的二分类任务，我们暂时把两类错误同等对待：把正常邮件错判为垃圾邮件，或把垃圾邮件错判为正常邮件，都记一次错误；分类正确则不记错误。这种计分方式称为 **零一损失** (zero-one loss)。设 $h(x)$ 是预测标签、 y 是真实标签，其公式为

$$\ell(h, (x, y)) = \ell_{01}(h(x), y) = \begin{cases} 1, & h(x) \neq y, \\ 0, & h(x) = y. \end{cases} \quad (4.3)$$

如果误删正常邮件的代价更高，就应另设损失；以下结论先以零一损失为评价标准。

一封邮件上的损失不能代表分类器的整体表现。假设一个分类器在 100 封已标注邮件中分错了 3 封，那么它在这批数据上的平均损失为 $3/100 = 0.03$ 。这个数可以直接计算，却只描述已经检查过的 100 封邮件。我们还希望知道：从今后会遇到的邮件中随机取出一封，这个分类器分错它的概率是多少？后一个问题必须考虑不同邮件出现的频率，而不只是当前样本中的计数。

用分布 $\mathcal{P}$ 表示输入及其真实标签的来源。它描述哪些分数的邮件更常出现，以及这些邮件分别属于哪一类。例如，即使两个假设只在一个很窄的分数区间内不同，如果大量邮件都集中在该区间，它们的整体表现仍可能差别很大。分布作用于输入与标签组成的观测 $z = (x, y) \in Z = X \times Y$ ，通常不为学习算法所知。

把零一损失代入定义 4.2，分类器 h 的期望风险就是随机邮件被分错的概率：

$$R_{\mathcal{P}}(h) = \mathbb{E}_{(x,y) \sim \mathcal{P}}[\ell_{01}(h(x), y)] = \mathbb{P}_{(x,y) \sim \mathcal{P}}(h(x) \neq y). \quad (4.4)$$

对样本 $S = (z_1, \dots, z_n)$ ，其中 $z_i = (x_i, y_i)$ ，定义 4.3 相应地变为

$$\hat{R}_S(h) = \frac{1}{n} \sum_{i=1}^n \ell_{01}(h(x_i), y_i). \quad (4.5)$$

它就是分类器在这份样本上分错的观测数占样本总数的比例。

两个记号的下标说明它们依赖什么： $R_{\mathcal{P}}$ 依赖数据分布， $\hat{R}_S$ 依赖具体样本。经验风险中的“经验”表示它由已观察数据计算，而非主观判断。若 S 就是训练集，经验风险就是训练集上的平均损失；在独立测试集上计算的错误比例则是对未来表现的另一次样本估计，仍不等于未知的期望风险。

同一个假设的期望风险减去经验风险，称为**泛化差** (generalization gap)，即 $R_{\mathcal{P}}(h) - \hat{R}_S(h)$ 。这个差值衡量样本上的平均损失与未来平均损失之间

的偏离，可以为正，也可以为负。它不同于后文的超额期望风险：后者比较两个期望风险，衡量学到的假设距离所选比较基准还有多远。

前面四封邮件上的两个阈值假设，经验风险都是零，但我们还不能算出它们的期望风险。为了看清缺少什么信息，可以再加入一个明确的教学假设：未来邮件的分数在 $[0, 1]$ 上均匀分布，并且真实类别恰好以 0.6 为界，分数不低于 0.6 才是垃圾邮件。此时阈值 0.6 的假设不会犯错，阈值 0.4 的假设则会把分数位于 $[0.4, 0.6)$ 的正常邮件误判为垃圾邮件。该区间占全部概率的 0.2，所以两个假设的期望风险分别为 0 和 0.2。这个计算依赖刚加入的分布和标签规律；它不是从那四封训练邮件推导出来的事实。

4.2.3 样本与学习算法

经验风险要帮助我们判断未来的期望风险，训练邮件就必须与未来邮件存在可说明的联系。最常用的理想化条件是**独立同分布**（independent and identically distributed, i.i.d.）抽样。“同分布”要求每个训练观测都来自评价未来表现时使用的同一个 $\mathcal{P}$ ；“独立”要求这些观测的联合概率按各自概率相乘。用 n 表示训练样本数，这个条件写成

$$S = ((x_1, y_1), \dots, (x_n, y_n)) \sim \mathcal{P}^n. \quad (4.6)$$

它不是对任何数据集都成立的事实。大量重复转发的邮件可能具有依赖，部署后的垃圾邮件类型也可能变化。后一种变化会使训练与评价不再同分布，需要第 9 章中的额外分析。

学习算法（learning algorithm）是根据训练样本选择假设的过程，记为 A 。算法读取 S 后输出分类器 $\hat{h} = A(S)$ 。例如，算法可以比较不同阈值在训练邮件上的错误数，并选出错误数最少的一个；若几个阈值都达到最少错误，它还必须规定如何选择。算法 A 是选择假设的方法，分类器 $\hat{h}$ 则是这次训练得到的具体假设，两者不能混为一谈。

本章暂取 $\mathcal{W}_{\text{out}} = \mathcal{H}$ ，所以算法进行的是第 4.1 节所说的恰当学习。若假设空间只包含单阈值假设，而算法组合多个假设得到一个不再是单阈值的分类器，就需要扩大输出空间；后文采用这种非恰当输出时会另行说明。

同一个算法用不同训练集可能选出不同分类器。仍以阈值分类器为例，一批邮件可能包含许多接近真实分界的样本，另一批可能恰好缺少这些邮件；即使算法完全相同，两次训练也可能得到不同阈值。因此，评价一个已经训练好的分类器，与评价一种学习算法的可靠性，是两个问题。

图 4.1 区分了这两种评价。固定训练结果 $\hat{h}$ 以后，期望风险 $R_{\mathcal{P}}(\hat{h})$ 只对一封新的随机邮件取平均。若重新抽取训练集并重新训练，输出 $A(S)$ 随之改变，期望风险 $R_{\mathcal{P}}(A(S))$ 也会改变。学习算法的可靠性取决于第二种变化：随机抽到一份训练集后，它有多大概率产生低期望风险分类器？算

法若还使用内部随机数，这个概率也要包含算法本身的随机性。




图 4.1 评价分类器与评价学习算法所涉及的两层随机性。固定一次训练的结果后，期望风险对右侧的新观测取平均；重新抽取左侧训练集则可能得到另一个分类器。学习保证还要控制后一种随机性导致训练失败的概率。

4.3 PAC 学习

PAC 学习（probably approximately correct learning）要求算法以较高概率得到误差较小的分类器。这里有两个不同的要求：所得分类器可以犯一些错误，但错误概率要足够小；随机抽取的训练集也可能使训练失败，但这种失败不能经常发生。PAC 分别用误差容限 ϵ 和失败概率容限 δ 表达这两项要求。

例如，要求“至少以 99% 的概率，得到未来错误率不超过 5% 的分类器”，就对应 $\delta = 0.01$ 和 $\epsilon = 0.05$ 。其中 5% 评价一次训练得到的分类器，99% 评价抽取训练集并训练这一整个过程。这个说法既不要求训练样本全部分对，也不保证每一批未来邮件的实际错误比例都恰好小于 5%。它约束的是分类器在数据分布上的错误概率。

有限样本可能遗漏某些输入，这使无条件、零失败的承诺通常无法满足。PAC 允许少量失败，但要求我们能通过足够多的样本，把失败概率控制到事先指定的水平。至于“误差小”应以零为目标，还是以当前假设空间能达到的最好结果为目标，则取决于数据是否允许完美分类。定义 4.4 已经给出这两类问题共用的概率量词。特化到二分类时，比较空间取 $\mathcal{H}$ ，损失取零一损失；可实现与不可知设定的差别落在允许分布族及其比较基准上。

4.3.1 可实现情形

可实现设定假定假设空间中存在一个不会在数据分布上犯错的假设。它把学习的困难集中在如何从有限观测中找到低期望风险假设，暂时不考虑标签噪声或假设空间遗漏真实规律造成的误差。

定义 4.5 可实现性 如果某个假设能够以概率 1 正确预测数据来源中的标签，就称数据分布对该假设空间是**可实现的** (realizable)。形式上，分布 $\mathcal{P}$ 对 $\mathcal{H}$ 可实现，是指存在 $h^* \in \mathcal{H}$ 满足

$$R_{\mathcal{P}}(h^*) = 0.$$

在前面的教学分布中，真实类别以分数 0.6 为界，而假设空间包含阈值 0.6 对应的假设，所以该分布对阈值假设空间可实现。若同一分数下既可能出现正常邮件，也可能出现垃圾邮件，单凭这个分数就无法总是判断正确；此时可实现性可能不成立。这里的条件针对全部可能观测，而不是针对某一张训练表。训练集碰巧没有矛盾，并不能证明总体上存在零错误分类器。

即使我们知道零期望风险假设存在，也不知道它是哪一个。学习保证需要说明：无论这个未知分布具体如何，只要它满足可实现性，一种预先确定的算法就能从足够多的样本中找到低期望风险假设。“足够多”可以随误差容限 ε 和失败概率容限 δ 变化，但不能依赖算法事先不知道的具体分布。

将定义 4.4 中的 $\mathfrak{P}$ 取为所有对 $\mathcal{H}$ 可实现的分布，并把样本量阈值 n_0 记为 $m_{\mathcal{H}}$ 。由于每个允许分布都满足 $\inf_{h \in \mathcal{H}} R_{\mathcal{P}}(h) = 0$ ，公共保证特化为

$$\mathbb{P}_{S \sim \mathcal{P}^n} (R_{\mathcal{P}}(A(S)) \leq \varepsilon) \geq 1 - \delta. \quad (4.7)$$

满足这一特化保证时，就说 $\mathcal{H}$ 在可实现设定下是 PAC 可学习的。同一个算法必须适用于所有允许的分布， $m_{\mathcal{H}}(\varepsilon, \delta)$ 只依赖误差容限、失败概率容限及假设空间。

在所有学习算法中，使上述保证对任意更大样本量都成立的最小样本量阈值，称为**样本复杂度** (sample complexity)。证明某个 $m_{\mathcal{H}}(\varepsilon, \delta)$ 满足上述条件，就给出了样本复杂度的上界；它未必是所需的最小值。若算法随机化，概率还包含其内部随机性。

式 (4.7) 应当从内向外读。 $A(S)$ 是本次训练得到的分类器； $R_{\mathcal{P}}(A(S)) \leq \varepsilon$ 表示这次训练成功，成功的标准是所得分类器的期望风险不超过误差容限；在零一损失下，这就是分类错误概率不超过 ε 。最外层的概率再询问，这个成功事件在随机抽取训练集时有多大概率发生，并要求它至少为 $1 - \delta$ 。

公共定义还规定了算法、样本量与分布之间的先后关系。我们不能先知道真实分布，再为它挑选专用算法，然后称这个假设空间可学习。同样，样本量上界也不能为每个未知分布临时另定。分布无关的保证要求同一上界覆盖所有允许分布，这比证明算法在某一个熟悉的数据来源上有效更强。PAC 的计算形式化由 Valiant 提出；这里采用统计学习教材中常用的分布无关表述¹。

减小 ϵ 和减小 δ 对应不同的改进。前者要求成功时得到更准确的分类器，后者要求更少发生训练失败。它们对样本量的影响不必相同；具体关系需要从假设空间和学习算法推导，不能只根据 PAC 的名称确定。第 5 章将给出有限假设空间中的样本量计算。

上述 PAC 保证允许要求任意小的 ϵ ，因此属于**强学习** (strong learning)。**弱学习** (weak learning) 则把任意精度要求放宽为一个固定优势。在二分类的可实现设定中，若存在 $\gamma \in (0, 1/2)$ 、同一个算法 A 和有限样本量函数 $m_{\mathcal{H}}^{\text{weak}}(\delta)$ ，使得对任意 $\delta \in (0, 1)$ 、任意对 $\mathcal{H}$ 可实现的分布 $\mathcal{P}$ 以及任意 $n \geq m_{\mathcal{H}}^{\text{weak}}(\delta)$ ，都有

$$\mathbb{P}_{S \sim \mathcal{P}^n, A} \left(R_{\mathcal{P}}(A(S)) \leq \frac{1}{2} - \gamma \right) \geq 1 - \delta,$$

就称 $\mathcal{H}$ 是弱 PAC 可学习的。这里 γ 不能随分布、样本或 δ 改变；算法随机化时，概率也包含其内部随机性。例如 $\gamma = 0.1$ 时，成功训练的错误率上限为 40%，优于不看输入、等概率猜两个标签的 50% 错误率。第 5.6 节反复调用弱学习器时，还会把目标假设空间与算法的输出空间分开写明。每轮改变的是样本权重所定义的分布；同一个算法和同一个优势必须对这些仍由目标空间实现的分布成立，各轮失败概率也要纳入总预算，不能把某一次训练略优于随机猜测当作这个接口。

4.3.2 不可知情形

可实现 PAC 保证有一个前提：假设空间中必须存在零期望风险假设。实际应用中，这个前提常常无法确认，甚至已经明确不成立。此时，不能把算法未达到零期望风险简单归因于训练失败；需要先判断当前输入信息与假设空间是否允许零期望风险假设存在。

输入信息不足就可能使零期望风险无法达到。假设评分程序将许多内容不同的邮件压缩成同一个分数 0.5，而这些邮件中 70% 是垃圾邮件、30% 是正常邮件。只读取分数的确定分类器必须对它们给出同一个答案：预测垃圾邮件会错 30%，预测正常邮件会错 70%。即使完全知道这两个比例，它也无法把这一组邮件全部分对。若分数 0.5 的邮件占总体的比例为 $q > 0$ ，这一组就至少贡献 $0.3q$ 的期望风险。标注噪声也可能造成类似的不确定性。如果把带噪声的观测标签作为 y ，这种噪声就包含在分布 $\mathcal{P}$ 中；若训

¹ L. G. Valiant, *A Theory of the Learnable* In Communications of the ACM, 1984, vol. 27, no. 11, pp. 1134–1142

练时使用带噪声标签、评价时使用另一套无噪声标签，则需要另外说明二者的关系，不能直接沿用同分布保证。

假设空间过于受限也会破坏可实现性，即使标签本身没有噪声。例如，三个分数 0.2、0.5、0.8 等概率出现，标签分别确定为 1、0、1。若允许任意分类函数，就存在零期望风险假设；若只允许随分数从 0 变成 1 的单阈值，便无法同时给出这三个标签。阈值取 0.6 时只错第一个输入，期望风险为 $1/3$ ；其他阈值也不能做到全对，所以这个假设空间的最低期望风险恰为 $1/3$ 。继续收集同一分布的数据，并不能补上假设空间缺少的表达能力。

这两种困难要求学习保证改变比较基准。我们仍然希望算法善用数据，但不再承诺假设空间中存在零期望风险假设，也不预先规定噪声应符合哪一种模型。**不可知设定** (agnostic setting) 就是在这样的条件下，要求学习结果接近当前假设空间能够达到的最低期望风险。“不可知”所放弃的是关于零期望风险目标假设的先验承诺，不是训练标签，也不是独立同分布假设。

假设当前假设空间能达到的最低期望风险为 8%。若仍要求分类器的期望风险不超过 2%，这个目标就无法实现。更合理的要求是：算法的期望风险比假设空间内最低值至多高 2 个百分点，也就是不超过 10%。学习结果高于假设空间内最低期望风险的差值，称为相对于假设空间的**超额期望风险** (excess risk)；这里允许的超额期望风险上限是 2 个百分点。这个差值度量学习结果还落后于同一假设空间中的最佳结果多少。

假设空间内最低期望风险记为 $R_{\mathcal{P}, \mathcal{H}}^*$ 。某些无限假设空间中的期望风险可以不断接近一个值，却没有成员恰好达到它，因此用下确界而不是最小值定义这个比较基准：

$$R_{\mathcal{P}, \mathcal{H}}^* = \inf_{h \in \mathcal{H}} R_{\mathcal{P}}(h). \quad (4.8)$$

例如一系列假设的期望风险为 $0.08 + 0.1/k$ 并随 k 增大接近 0.08，0.08 就可以是下确界，即使没有假设的期望风险恰好等于 0.08。这个数学例子说明，下确界允许我们讨论最佳可逼近水平，而不额外假定最优假设一定存在。

若将定义 4.4 中的 $\mathfrak{P}$ 取为 $X \times Y$ 上的全部相关联合分布，并把样本量阈值记为 $m_{\mathcal{H}}^{\text{agn}}$ ，公共保证相应地写成

$$\mathbb{P}_{S \sim \mathcal{P}^n} \left(R_{\mathcal{P}}(A(S)) \leq R_{\mathcal{P}, \mathcal{H}}^* + \varepsilon \right) \geq 1 - \delta. \quad (4.9)$$

满足这一特化保证时，就说 $\mathcal{H}$ 是**不可知 PAC 可学习的** (agnostic PAC learnable)。这里的误差容限 ε 约束超额期望风险，而不是分类器的全部期望风险。

这个保证也覆盖可实现分布。此时假设空间内最低期望风险为零，式 (4.9) 就恢复为可实现 PAC 保证。因此，不可知学习扩大了需要覆盖的数据分布范围，对算法的统一能力提出了更强要求；它并不是把成功标准

任意降低。算法不需要事先知道假设空间内最低期望风险的数值，正如可实现学习不需要事先知道哪个假设具有零期望风险；这个数值用于评价算法的结果。

4.3.3 计算要求

前面的统计保证主要回答有限数据是否足以支持可靠预测。在这种表述中，学习算法只是从样本到分类器的一个映射；证明这样的映射存在，还没有提供计算机能够执行的程序。

把映射落实为程序，还要回答程序是否停机，以及所需计算量怎样随问题规模增长。可计算 PAC 学习与高效 PAC 学习分别补充这两层要求，同时保留相应的 PAC 期望风险保证。

讨论程序之前，必须说明数据和假设怎样编码。以自然数输入为例，每个输入可以写成二进制字符串，标签只需一个比特；一个分类器则可用计算其预测的程序表示。学习程序的输出是这个预测程序的有限描述。任意实数不一定有有限的精确编码，因此不能把连续输入中的一次任意精度计算默认当作常数时间操作；必须另行约定精度或计算模型。

定义 4.6 可计算 PAC 学习 在固定的有效表示下，如果存在一个可执行的学习程序，能够在每个允许的有限训练样本上停机，输出一个对每个允许输入都能停机并给出标签的预测程序，并且该学习算法满足 PAC 保证，就称该假设空间是可计算 PAC 可学习的 (computably PAC learnable)，简称 CPAC 可学习。这里的 PAC 保证可以采用可实现版本或不可知版本，使用时必须说明采用哪一种。

这个定义同时约束训练和预测。仅仅说“输出期望风险最小的假设”没有告诉计算机怎样找到该假设；仅仅输出一段可能永远不返回预测的代码，也没有给出可用的分类器。另一方面，可计算性允许非常缓慢但最终会完成的计算，并不要求多项式时间。若还要求输出属于 $\mathcal{H}$ ，得到恰当 CPAC 学习；允许输出假设空间之外的分类器时则得到非恰当版本。本章仍沿用恰当输出的默认约定，比较文献结论时需要检查这一约定。

学习程序能够执行，与所需样本量上界能够计算，也有区别。前者保证拿到一份样本后能够完成训练，后者使我们能根据 ϵ, δ 计算一个足够大的样本数。基本 CPAC 定义不自动要求后者；文献还研究附加可计算样本上界的版本。这些区分及其分离结果可见 Delle Rose 等的研究²。第 5.7 节将用可计算的缺失标记继续分析它们。

即使训练程序一定停机，穷举搜索仍可能过慢。假设一个假设空间由 d 比特索引指定，共有 2^d 个假设，并且给定索引后可以在多项式时间内计算预测。逐一计算全部假设的经验风险就能完成有限搜索，但需要检查指

² V. Delle Rose, A. Kozachinskiy, C. Rojas, T. Steifer, *Find a Witness or Shatter: The Landscape of Computable PAC Learning* In Proceedings of the 36th Conference on Learning Theory, 2023, pp. 511–524

数多个假设。定理 5.1 将说明，在可实现情形下，充分样本量只按

$$\frac{d \log 2 + \log(1/\delta)}{\varepsilon}$$

增长。样本数对 d 的线性依赖与穷举计算量的指数依赖并不矛盾：观察多少数据和怎样搜索假设是两种资源问题。这只能说明穷举算法很慢，不能由此断言该假设空间不存在更快的学习算法。

定义 4.7 高效 PAC 学习 高效 PAC 学习 (efficient PAC learning) 要求在满足 PAC 期望风险保证的同时，样本量、训练计算量及输出分类器的预测计算量都有多项式上界。为明确规模依赖，考虑由参数 d 描述的一族假设空间 $\mathcal{H}_d$ ，并约定观测编码长度上界为 b 。本书采用的高效性约定要求存在统一程序和固定多项式 p, q ，使所需样本量及训练时间分别满足

$$\begin{aligned} m_{\mathcal{H}_d}(\varepsilon, \delta) &\leq p(d, b, 1/\varepsilon, \log(1/\delta)), \\ T_{\text{train}} &\leq q(n, d, b, 1/\varepsilon, \log(1/\delta)). \end{aligned} \quad (4.10)$$

输出分类器在新输入上的求值时间也应被其表示长度和输入编码长度的某个固定多项式所控制。若这族假设空间还由目标描述长度等量参数化，也须将它们明确列入规模变量。

这里的 d 表示已经约定的假设空间规模参数，不总是特征维数； b 避免把任意长度的数值读写与比较算作一次免费操作。多项式的次数不能随着 d 增大而增大，否则“对每个固定 d 都能运行”仍可能掩盖指数增长。不同文献对失败概率参数采用 $1/\delta$ 或 $\log(1/\delta)$ 等约定，引用高效性结论时必须核对具体定义。多项式保证也不是实际运行速度的承诺，大常数与高次数仍可能使程序难用。

有序阈值说明怎样利用结构减少搜索。设输入为整数 $1, \dots, M$ ，假设为 $h_t(x) = \mathbb{I}\{x \geq t\}$ ，其中 $t \in \{1, \dots, M+1\}$ 。虽然有 $M+1$ 个阈值假设，训练样本上的预测只有在阈值跨过一个已观察输入时才会改变。算法可以先排序，将重复输入分组，再扫描各组之间的切分位置，累计左侧正标签和右侧负标签的个数，从而选出经验风险最小的阈值。排序需要 $O(n \log n)$ 次比较，扫描需要 $O(n)$ 次累计，不必逐一检查全部 $M+1$ 个假设；每次整数操作的位成本还需按 $\log M$ 计算。新输入的预测只需与所选阈值比较。结合有限假设空间的样本界，这个例子在所述编码下满足高效 PAC 要求。

在相同的期望风险目标、表示和输出约定下，高效 PAC 可学习必然推出可计算 PAC 可学习，可计算 PAC 可学习又必然推出 PAC 可学习。反向推断需要额外依据。可实现与不可知规定允许怎样的数据分布，恰当与非恰当规定允许输出什么，而可计算与高效规定如何执行学习；它们约束的

是不同方面。

4.4 学习的限制

学习算法看不到未知的期望风险，却能够计算假设在训练样本上的经验风险。因此，一个直接的训练办法是选择经验风险最小的假设。前面的两条阈值假设都是这种办法可能返回的结果，因为它们在四封训练邮件上都没有错误。

定义 4.8 经验风险最小化 经验风险最小化 (empirical risk minimization, ERM) 是在给定假设空间中，选择训练样本平均损失最小的假设作为学习结果。用 A_{ERM} 表示这种学习算法，则

$$A_{\text{ERM}}(S) \in \arg \min_{h \in \mathcal{H}} \hat{R}_S(h). \quad (4.11)$$

这里 $\arg \min$ 表示所有达到最小经验风险的假设组成的集合。若最小值不能取得，可以要求输出的经验风险与下确界相差不超过一个给定容差。

公式中的集合符号“ $\in$ ”保留了一个重要区别：经验风险最小的假设可能不止一个。ERM 原则只要求从这些假设中选择，并没有说明选哪一个。阈值 0.4 和 0.6 的例子已经表明，经验风险相同的假设可能在新输入上不同。要判断 ERM 能否满足 PAC 保证，还必须控制这种未观察区域中的差异。

这个困难不只是训练样本少。若假设空间能随着样本构造出大量特殊假设，增加有限数量的训练数据也可能只是让算法记住更长的一张表。下面的反例用一个极端的记忆假设说明，经验风险达到零与期望风险很小之间，可以没有任何必然联系。

4.4.1 记忆训练样本

考虑一个有意简化的输入数据：邮件的特征是 0 到 1 之间的分数，服从均匀分布，即落入一个区间的概率等于该区间的长度，但全部邮件的真实标签都是垃圾邮件。

我们有两个假设。第一个假设预测所有邮件是垃圾邮件。这个假设在该数据分布下永远不会犯错。另一个假设却可以只记住训练邮件的分数：新邮件的分数如果恰好在记忆表中，就预测垃圾邮件；只要没有出现过的，就预测正常邮件。

用 C 表示记忆表中的有限分数集合，这个假设写成

$$h_C(x) = \begin{cases} 1, & x \in C, \\ 0, & x \notin C, \end{cases} \quad (4.12)$$

并令 $h_{\text{all}}(x) = 1$ 对所有 x 成立。假设空间取为所有 h_C 与 h_{all} 的集合。这些函数都是可测的，而且 h_{all} 的期望风险为 0，所以当前分布对该假设空间可实现。

对训练集 S ，记其中出现过的不同输入组成有限集合 C_S 。若 ERM 在所有经验风险为零的假设中选择 h_{C_S} ，便会得到

$$\hat{R}_S(h_{C_S}) = 0, \quad R_{\mathcal{P}}(h_{C_S}) = 1. \quad (4.13)$$

第一个等式成立，因为每个训练输入都属于 C_S ；第二个等式成立，因为连续均匀分布落在任意有限集合上的概率都是 0。这个分类器精确记住了训练输入，却把几乎所有新输入判错。

示例没有证明所有 ERM 都会失败。选择 h_{all} 的 ERM 在同一问题上期望风险为 0。它说明的是：经验风险最小只约束假设在已经观察到的点上怎样作答；如果假设空间允许任意延拓，ERM 原则本身不能控制未见区域。第 5.2 节的一致收敛将给出一种条件，使所有经验风险最小解都不会在期望风险上远离假设空间内的最佳水平。

4.4.2 没有免费的午餐

前面的记忆型反例只展示了一个糟糕的 ERM 选择。如果换一种算法，是否就能在不限制标签规律的情况下保证泛化？**没有免费的午餐**（no-free-lunch）定理说明，只要假设空间允许在足够多的输入上自由指定标签，任何只观察有限样本的算法都会遇到无法可靠判断的数据分布。

具体地，假设算法只能获得 n 个训练样本，而输入空间中至少有 $2n$ 个不同的点。再假设假设空间足够丰富，能够实现这 $2n$ 个点上的任意标签组合。在这些条件下，无论采用哪一种学习算法，我们都能为它构造一个数据分布，使得假设空间中虽然存在零期望风险假设，算法仍有较大的概率学到期望风险较高的分类器。后面的定理将给出明确的数值：算法学到的分类器，期望风险不低于 $1/8$ 的概率至少为 $1/7$ 。

构造这个分布，就是规定哪些输入会出现、各以多大概率出现，以及它们的标签是什么。算法没有被告知完整分布，只能观察从中抽取的 n 个样本。由于样本无法覆盖这 $2n$ 个输入，而不同输入的标签又没有预先规定的联系，算法即使找到了能分对全部训练样本的假设，也可能在未见输入上大量出错。这里的失败指期望风险超过要求的容限，并不是经验风险不为零。

先看四个编号的例子。假设输入空间为 $X = \{1, 2, 3, 4\}$ ，编号只用于区分输入，不表示大小、相似性或类别关系。每个编号等概率出现，假设空间包含全部二分类假设。某次训练只观察到 $(1, 0)$ 和 $(2, 1)$ ：算法知道编号 1 的标签是 0、编号 2 的标签是 1，还没有观察到编号 3 和 4 的标签。

这些已知信息允许多种不同的完整标签表。例如，一种可能是四个编号的标签依次为 $(0, 1, 0, 0)$ ，记为 f_0 ；另一种可能是 $(0, 1, 1, 1)$ ，记为 f_1 。两者都把编号 1 标为 0、编号 2 标为 1，因此都能解释已经观察到的训练数据。这就是“两条标签规律都与样本一致”的含义，并不是说它们在所有输入上都给出相同标签。图 4.2 把相同的训练样本与两种隐藏真值并列。




图 4.2 同一训练样本不能排除两种相反的隐藏真值。四个输入各以 $1/4$ 的概率出现；两种来源在已见的编号 1、2 上分别标为 0、1，在未见编号 3、4 上分别全标为 0 或全标为 1。图中固定输出取 $h(3) = 0, h(4) = 1$ ，勾、叉直接标出它在两个来源中各错一个未见输入。给定一样本和算法内部随机数，两种来源中必有同一输出；对任意二分类预测，每个未见输入的两份零一损失之和都是 1，故风险之和至少为 $1/2$ 。此图展示固定样本的信息缺口；下文定理再处理随机训练样本。

现在要求算法预测编号 3。若真实标签表是 f_0 ，正确答案就是 0；若真实标签表是 f_1 ，正确答案就是 1。但在这两种可能情况下，算法已经收到的训练数据完全相同，都是 $(1, 0)$ 和 $(2, 1)$ ，其中没有任何信息能够排除一种可能、保留另一种可能。算法可以按照某种偏好猜测编号 3 的标签，却不能仅凭这份样本保证猜对。

枚举假设也不能消除这个区别：算法能够找到 f_0 和 f_1 ，也能确认它们的经验风险都是零，但仍无法据此判断哪一条在编号 3 上正确。这里缺少的是未见输入的标签信息，或把已见标签与未见标签联系起来的额外假设。

这个风险相加的关系可以推广到 n 个训练观测与 $2n$ 个等概率输入。固定这份样本，未见输入集合 U 至少有 n 个点；让两个候选标签表在已见处一致，在 U 上处处相反。对同一个输出 h ，每个未见点的两份零一损失之和都是 1，因此

$$R_{\mathcal{P}_0}(h) + R_{\mathcal{P}_1}(h) \geq \frac{|U|}{2n} \geq \frac{1}{2}.$$

两种来源中至少有一种使这次输出的风险不低于 $1/4$ 。这里的候选标签表是在固定样本下用于展示歧义；要证明随机抽样时仍存在困难的固定分布，还需要下面的平均论证。

为此，我们对全部标签配置取平均，从而找到一个在随机抽样下仍然困难的固定分布。这是统计学习中的没有免费的午餐结论³。

³ S. Shalev-Shwartz, S. Ben-David, *Understanding Machine Learning: From Theory to Algorithms*, Cambridge University Press, 2014, 1st ed.

定理 4.9 没有免费的午餐 设 $n \geq 1$ ，固定输入空间 X 中有一个含 $2n$ 个不同点的集合 C 。假设无论怎样为 C 中的每个点分别指定标签 0 或 1，都能从 $\mathcal{H}$ 中找到一个分类器，使它在 C 上的预测与这些指定标签完全一致；不同的标签组合可以由 $\mathcal{H}$ 中的不同分类器实现。则对任意使用 n 个独立同分布训练观测的二分类学习算法 A ，都存在一个对 $\mathcal{H}$ 可实现的分布 $\mathcal{P}$ 及 $f^* \in \mathcal{H}$ ，使 $R_{\mathcal{P}}(f^*) = 0$ ，但

$$\mathbb{P}\left(R_{\mathcal{P}}(A(S)) \geq \frac{1}{8}\right) \geq \frac{1}{7}. \quad (4.14)$$

这里概率对 $S \sim \mathcal{P}^n$ 及算法内部随机性计算。算法即使允许输出 $\mathcal{H}$ 以外的分类器，结论也成立。

证明. 证明中所有分布都把输入均匀放在固定集合 C 上，只改变标签规律。对每张标签表 $g: C \rightarrow \{0,1\}$ ，按定理前提选择一个在 C 上与 g 一致的 $f_g \in \mathcal{H}$ 。定义分布 $\mathcal{P}_g$ 为：先等概率选择 C 中的输入 x ，再把标签确定为 $g(x)$ 。这样，每个 $\mathcal{P}_g$ 在假设空间内都有零期望风险假设 f_g 。

为了从这些分布中找出一个困难者，暂时随机选择标签表：对 C 中的每个点独立抛一次公平硬币，以结果决定该点的标签。每个点只抛一次，之后再抽到同一个点时标签不变。因此，每个固定标签表对应的分布都没有标签噪声，仍然可实现；随机化标签表只是证明中的平均方法。

固定抽到的 n 个训练输入、它们的标签及算法的内部随机数。样本至多包含 n 个不同输入，所以 C 中至少有 n 个输入未被观察。对任何未见输入 x ，算法的预测已经由已知信息确定，但该点的随机标签仍以相同概率为 0 或 1，与已知标签独立。因此，无论算法预测哪一类，它猜错这个未见标签的条件概率都是 $1/2$ 。

每个未见输入占总体概率 $1/(2n)$ 。只累加这些输入对期望风险的贡献，就得到在随机标签表下的平均期望风险至少为

$$n \times \frac{1}{2n} \times \frac{1}{2} = \frac{1}{4}. \quad (4.15)$$

式中的三个因子依次是未见输入数量的下界、每个输入出现的概率和猜错其标签的概率。再对训练输入、已知标签与算法随机数取平均，这个下界仍成立，即 $\mathbb{E}_g \mathbb{E}_{S,U} R_{\mathcal{P}_g}(A(S,U)) \geq 1/4$ ，其中 U 表示算法内部随机数。

有限张标签表的平均值至少为 $1/4$ ，就必有一张固定表 g^* 使

$$\mathbb{E}_{S,U} R_{\mathcal{P}_{g^*}}(A(S, U)) \geq \frac{1}{4}.$$

否则每张表对应的期望都小于 $1/4$ ，它们的平均也会小于 $1/4$ 。至此固定 $\mathcal{P} = \mathcal{P}_{g^*}$ 与 $f^* = f_{g^*}$ ；今后的概率只来自按这个固定分布抽样和算法内部随机性。

对样本和算法随机性取平均后，期望风险至少为 $1/4$ ；还需把这个平均值下界转成训练失败概率下界。令 $Z = R_{\mathcal{P}}(A(S, U)) \in [0, 1]$ ， $p = \mathbb{P}(Z \geq 1/8)$ 。在概率为 $1 - p$ 的事件上， $Z < 1/8$ ；在其余事件上， $Z \leq 1$ 。因此

$$\frac{1}{4} \leq \mathbb{E}Z \leq (1 - p)\frac{1}{8} + p = \frac{1}{8} + \frac{7}{8}p.$$

整理得到 $p \geq 1/7$ ，完成证明。 ■

定理中的先后顺序很重要。先选定学习算法 A 和样本量 n ，证明再根据二者确定一个困难分布 $\mathcal{P}$ 。分布 $\mathcal{P}$ 一旦确定，输入的出现概率和标签便随之固定；之后每次训练都从同一个 $\mathcal{P}$ 独立抽取 n 个观测，不能在看到某次训练样本后再修改未见输入的标签。在这些重复训练中，算法输出一个期望风险不低于 $1/8$ 的分类器的概率至少为 $1/7$ 。因此，证明找到的是一个固定的数据来源，而不是事后挑选一份碰巧对算法不利的训练样本。

这里的困难分布可以依赖学习算法和样本量：对每个算法和每个给定的 n ，只要假设空间能在足够多个输入上实现任意二元预测，就能找到一个使该算法在这个样本量下失败的数据分布。它没有断言该算法在所有数据分布上都会失败，也没有断言所有算法在同一个数据分布上表现相同。某个算法完全可能在许多具有特定结构的数据分布上成功；没有免费的午餐排除的是对所有允许分布都有效的无条件保证。

前面的定理只考察一种给定的样本量 n ：当算法只能看到 n 个训练观测，而假设空间能在至少 $2n$ 个输入上自由指定标签时，可以构造一个使该算法失败的数据分布。取固定的无限输入空间，例如 $X = \mathbb{N}$ ，并令 $\mathcal{H}$ 包含其上的全部二分类函数。假如存在 PAC 学习器，固定 $\varepsilon = 1/16$ 、 $\delta = 1/8$ ，它应有一个有限的统一样本上界 $n \geq 1$ 。但同一个 X 中总能选出 $2n$ 个点，定理便给出一个对 $\mathcal{H}$ 可实现的分布，使期望风险至少为 $1/8$ 的概率不低于 $1/7$ 。这既超过误差容限 $1/16$ ，失败概率也超过 $1/8$ ，与 PAC 保证矛盾。因而不可学习的是这个不受限制的假设空间在全部可实现分布上的统一学习问题，不是说每一个具体分布都不能学习。

在上述构造中，零期望风险分类器 f^* 确实属于 $\mathcal{H}$ 。可以把 f^* 看成一张完整的答案表：它记录了每个输入应当取标签 0 还是标签 1。学习算法却不会直接得到这张答案表，只能看到随机抽取的 n 个带标签观测。如果某个编号没有出现在训练样本中，那么样本既可能来自“该编号的标签为

0”的答案表，也可能来自“该编号的标签为1”的答案表；这两张表在所有已观察编号上可以完全相同。训练数据因而没有提供判断这个未见标签所需的信息。

所以，“有解却找不到”并不是说正确答案藏在一个过大的搜索空间中，算法来不及搜索。即使不限制算法的计算资源，样本仍然可能与多个假设完全一致，而这些假设在未见输入上给出不同预测。算法无法仅凭现有样本判断哪一个对应真实标签。这里缺少的是信息，而不是计算能力。第4.3.3节讨论的程序不可计算或运行时间过长，则属于另一类问题。

PAC学习并不要求算法找回整张答案表，也不要求输出与 f^* 处处相同；它只要求输出分类器的期望风险不超过给定的 ϵ 。没有免费的午餐定理表明，对于不受限制的假设空间，任何算法提出一个有限的统一样本量后，都能找到一个允许的数据分布，使它在该样本量下达不到规定的误差与置信度要求。因此，无法找到一个对所有允许分布都有效的有限样本量。

要得到正面的学习保证，必须加入某种能够把已见输入与未见输入联系起来的限制。以阈值假设 $h_t(x) = \mathbb{I}\{x \geq t\}$ 为例，如果分数0.5的邮件被标为1，那么阈值必定不大于0.5，于是所有分数高于0.5的邮件也会被标为1；一个已见标签由此排除了许多假设，并约束了未见输入的预测。若允许每个编号的标签彼此独立地任意取0或1，观察编号1的标签便不会提供关于编号2的任何信息。

因此，限制假设空间或对数据分布作出假设，实质上是在规定哪些标签规律可以从已见样本推广到未见输入。不过，限制过强也可能把真正需要的假设排除在外，这正是下一节讨论模型选择时需要处理的问题。

4.5 模型选择

限制假设空间有助于排除记忆型解，但限制过强又可能使好假设根本不在假设空间内。例如，真实的垃圾邮件分数如果集中在两个彼此分离的区间，单个阈值就不能同时圈出这两个区间而排除中间的正常邮件。样本再多，也不能改变单阈值的这种表达限制。

这里需要区分两种来源不同的错误。第一种错误来自输入空间所包含的信息。回到分数为0.5的邮件例子：其中70%是垃圾邮件，30%是正常邮件，但分类器得到的输入只有邮件分数。对分类器而言，这些邮件都表示为同一个输入 $x = 0.5$ ，因而任何分类器 $h : X \rightarrow \{0, 1\}$ 都只能给它们一个共同的预测。若预测为垃圾邮件，就会把其中30%的正常邮件分错；若预测为正常邮件，则会把70%的垃圾邮件分错。因此，即使不限制假设空间，允许算法学习任意分类函数，仍然至少会出现30%的条件错误。只要输入仍然只有这个分数，增加样本或更换学习算法都不能消除这部分错误。

第二种错误来自假设空间的限制。考虑分数为0.2、0.5和0.8的三类邮

件，其标签依次确定为 1、0 和 1。这里的输入足以区分三类邮件，而且确实存在能够把它们全部分对的假设；但是，单阈值假设空间 $\mathcal{H}$ 不能表示先预测 1、再预测 0、最后又预测 1 的规律，所以 $\mathcal{H}$ 中的每个假设都至少错一类邮件。此时无法得到零期望风险假设，并不是输入没有提供足够信息，而是 $\mathcal{H}$ 没有包含所需的假设。

因此，评价一个假设空间时，应先确定在当前输入信息下任何分类器都无法避免的最低期望风险，再考察受限假设空间是否在此基础上引入了额外错误。前一种最低期望风险将由贝叶斯风险刻画。

贝叶斯风险 (Bayes risk) 是在给定输入空间下，所有可测分类器能够达到的最低错误概率。它不限制分类器必须属于我们选定的假设空间 $\mathcal{H}$ ，因此可以作为评价不同假设空间的共同基准。令 $\mathcal{F}$ 表示所有可测二分类器，定义

$$R_{\mathcal{F}}^* = \inf_{h \in \mathcal{F}} R_{\mathcal{P}}(h). \quad (4.16)$$

贝叶斯风险是假定知道数据规律时能够达到的水平，不表示学习算法实际上知道这些规律。

为了找出所有分类器能够达到的最低期望风险，先固定一个输入 x ，只考虑在这个输入上应当预测哪个标签。即使输入固定为 x ，标签也不一定固定：在所有输入为 x 的观测中，一部分标签可能为 1，其余标签为 0。记

$$\eta(x) = \mathbb{P}(y = 1 \mid x),$$

即输入为 x 的条件下，标签为 1 的概率。相应地，标签为 0 的概率为 $1 - \eta(x)$ 。

分类器面对输入 x 时只能选择一个标签。如果预测 1，那么只有真实标签为 0 时才会出错，错误概率为 $1 - \eta(x)$ ；如果预测 0，那么真实标签为 1 时会出错，错误概率为 $\eta(x)$ 。为了使错误尽可能少，应当选择这两个概率中较小的一个。因此，当 $\eta(x) \geq 1/2$ 时预测 1，当 $\eta(x) < 1/2$ 时预测 0。按照这一原则对每个输入作出预测的分类器称为**贝叶斯分类器** (Bayes classifier)；在通常的可测性假设下，可以写成

$$h^*(x) = \mathbb{I}\{\eta(x) \geq 1/2\}.$$

它在输入 x 处仍然会犯错的概率为

$$\min\{\eta(x), 1 - \eta(x)\}.$$

例如，在所有分数为 0.5 的邮件中，若 70% 是垃圾邮件，则 $\eta(0.5) = 0.7$ 。贝叶斯分类器会把分数为 0.5 的邮件统一预测为垃圾邮件；这样会分错其余 30% 的正常邮件。预测为正常邮件会错 70%，所以 30% 已经是只观察该分数时能够达到的最低条件错误率。

要从每个输入处的最低错误率得到总体风险, 还须考虑不同输入出现的频率。若分数为 0.5 的邮件只占全部邮件的 q , 上述 30% 的条件错误对期望风险的贡献就是 $0.3q$ 。记 $\mathcal{P}_X$ 为输入的**边缘分布** (marginal distribution): 它由联合分布 $\mathcal{P}$ 忽略标签后得到, 只记录各种输入出现的概率。按照 $\mathcal{P}_X$ 对每个输入处的最低错误率加权平均, 便得到贝叶斯风险

$$R_{\mathcal{P}}^{\star} = \mathbb{E}_{x \sim \mathcal{P}_X} [\min\{\eta(x), 1 - \eta(x)\}].$$

因此, 只要某些输入可能对应不同标签, 即使已经知道完整的数据分布并采用贝叶斯分类器, 贝叶斯风险仍可能大于零。

4.5.1 两类误差

学习结果与贝叶斯风险之间的差距, 可以分别归因于假设空间的表达限制, 以及算法依据有限样本作出的选择。

近似误差 (approximation error) 是假设空间内最低期望风险高于贝叶斯风险的部分。它描述假设空间没有包含更好假设所付出的代价, 即使有无限数据并能精确找到假设空间内最佳假设, 这部分差距也不会自动消失。

估计误差 (estimation error) 是算法输出假设的期望风险高于假设空间内最低期望风险的部分。它描述我们依据有限样本选出的假设还落后于空间内最佳水平多少。这里按期望风险差来定义该项, 所以它也会受具体学习过程影响, 不能理解成与算法无关的纯粹抽样误差。

假设 $\hat{h} = A(S) \in \mathcal{H}$, 把假设空间内最低期望风险加上再减去, 便得到

$$\begin{aligned} R_{\mathcal{P}}(\hat{h}) - R_{\mathcal{P}}^{\star} &= \left(\inf_{h \in \mathcal{H}} R_{\mathcal{P}}(h) - R_{\mathcal{P}}^{\star} \right) \\ &\quad + \left(R_{\mathcal{P}}(\hat{h}) - \inf_{h \in \mathcal{H}} R_{\mathcal{P}}(h) \right). \end{aligned} \quad (4.17)$$

右侧第一项是近似误差, 第二项是估计误差。因为 $\mathcal{H}$ 包含于所有可测分类器中, 假设空间内最低期望风险不会低于贝叶斯风险; 又因为 $\hat{h} \in \mathcal{H}$, 实际输出不会优于空间内期望风险的下确界。因此两项都非负。若允许输出假设空间之外的分类器, 第二项可能为负, 就不能再作同样的非负误差解释。

例如, 假设贝叶斯风险为 5%, 阈值假设空间内的最低期望风险为 12%, 实际学到的阈值假设的期望风险为 15%。那么假设空间的近似误差是 7 个百分点, 算法输出的估计误差是 3 个百分点, 两者相加正好是高于贝叶斯风险的 10 个百分点。增加训练数据主要帮助算法降低估计误差; 但若消除假设空间自身留下的 7 个百分点, 还需要改变输入表示或扩大假设空间。

图 4.3 把贝叶斯风险、假设空间内最低期望风险和输出假设的期望风险放在同一方向上比较。近似误差连接贝叶斯风险与假设空间内最低期望风险，表示假设空间的表达限制；估计误差连接假设空间内最低期望风险与实际输出的期望风险，表示有限样本下没有选到假设空间内最佳假设所付出的代价。




图 4.3 近似误差与估计误差的期望风险分解。这个教学示例中，当前输入信息决定的贝叶斯风险为 5%；阈值假设空间的表达限制把空间内最低期望风险提高到 12%，二者相差 7 个百分点；学习算法依据有限样本得到的分类器的期望风险为 15%，又比空间内最低期望风险高 3 个百分点。实线与虚线分别标出近似误差和估计误差。

更丰富的假设空间通常能降低近似误差，因为它拥有更多假设；但学习算法也更容易在有限样本中找到偶然拟合良好的函数，使估计误差难以控制。这就是所谓的 **偏差与复杂度的权衡** (bias-complexity trade-off)：这里的“偏差”指假设空间的表达限制，“复杂度”指从有限样本中可靠选择假设所付出的统计代价。

以阈值和区间为例，若真实正类由两个分离区间组成，单阈值假设空间即使得到无限数据也会留下系统性错误，这部分属于近似误差。改用允许许多小区间的假设空间后，训练点可以被细致包围，近似误差下降；但有限样本没有覆盖到的间隙也可能被误判，估计误差可能增加。扩大假设空间会改变式 (4.17) 右侧两项，却不必然改善最终期望风险。结构风险最小化据此要求：选择更丰富的假设空间所带来的拟合改善，应当足以补偿新增的统计不确定性。

经验优化误差 (empirical optimization error) 是算法输出的经验风险与假设空间内最低经验风险之间的差距。例如，训练集中最好的假设只错 2 封，算法却返回一个错 5 封的假设，多出的 3 次错误反映的是训练目标尚

未达到最优。它与前面的期望风险分解不是同一个比较。对输出 $\hat{h}$ ，经验优化误差定义为

$$\Delta_{\text{opt}}(S) = \hat{R}_S(\hat{h}) - \inf_{h \in \mathcal{H}} \hat{R}_S(h) \geq 0, \quad (4.18)$$

这个量比较的是经验目标，不能把式 (4.17) 任意改写成三个非负期望风险差。后续分析通常先用泛化界把经验量与期望量联系起来，再说明 $\Delta_{\text{opt}}(S)$ 怎样进入最终保证。

4.5.2 用验证集选择模型

比较不同复杂度的候选模型时，训练误差只能说明它们对训练样本拟合得怎样。如果假设空间逐渐扩大，而且每次都求到空间内的最小经验风险，训练误差不会随复杂度增加而上升；这仍不能保证新样本上的误差也下降。可以另留一份不参与参数拟合的 **验证集**，比较候选模型在这些观测上的误差，再据此选择复杂度或其他超参数。

图 4.4 用一组教学曲线展示这种选择。训练误差持续下降，验证误差却在复杂度继续增大后回升，因此选择落在最低验证误差处，而不是训练误差最低处。这里的 U 形用于说明可能出现的过拟合；实际验证曲线不一定只有一个谷底。验证集已经参与模型选择，所以还应保留独立的 **测试集**：锁定模型和超参数后，只对最终模型作一次评价。反复查看测试误差并据此改模型，会使测试集也参与选择，失去这次独立评价的作用。




图 4.4 用验证误差选择模型，再独立测试。实线圆点表示训练误差，虚线方块表示验证误差；圆环标出的最低验证误差决定所选复杂度 $\hat{k}$ 。三角形仅表示选定模型的一次测试误差，不参与选择，也不连成测试曲线。曲线和测试点均为人为构造的教学示意，不是实验结果。

4.5.3 结构风险最小化

假设现在有一列逐渐丰富的假设空间 $\mathcal{H}_1 \subseteq \mathcal{H}_2 \subseteq \dots$ 。在邮件例子中, $\mathcal{H}_k$ 可以允许至多 k 个区间的并作为正类区域; 这样每个假设空间都包含前一个空间中的假设。如果只按经验风险选择假设空间, 空间越丰富, 空间内最小经验风险只会下降而不会上升, 因而选择会偏向最丰富的假设空间; 如果只为压低估计误差而选择最简单的假设空间, 又可能造成很大的近似误差, 也就是偏差。因此, 选择假设空间时需要在近似误差 (偏差) 与估计误差之间进行权衡。

结构风险最小化 (structural risk minimization, SRM) 是一种在近似误差与估计误差之间选择假设空间的方法。这两个期望风险差都依赖未知分布, 算法无法直接计算, 因此实际采用带惩罚的经验风险作为选择标准。固定总失败概率 δ , 给第 k 个假设空间预先分配失败概率 $\delta_k > 0$, 使 $\sum_{k \geq 1} \delta_k \leq \delta$ 。记 $\text{pen}(k, n, \delta_k)$ 为第 k 个假设空间的复杂度惩罚, 结构风险最小化选择

$$(\hat{k}, \hat{h}) \in \arg \min_{k \geq 1, h \in \mathcal{H}_k} \{\hat{R}_S(h) + \text{pen}(k, n, \delta_k)\}. \quad (4.19)$$

经验风险 $\hat{R}_S(h)$ 衡量假设在训练样本上的错误, 惩罚项则控制从经验风险推断期望风险时的不确定性。它通常随假设空间复杂度增大而增大, 可视作为对估计误差的高概率控制量, 而不是估计误差本身。惩罚过小, 经验风险较低但只是在样本上偶然拟合良好的复杂假设仍可能胜出; 惩罚过大, 选择又会偏向表达能力不足的简单假设空间, 造成较大的近似误差 (偏差)。若式中的最小值不能取得, 可以像 ERM 一样使用带惩罚经验目标的近似最小解。

失败概率的分配用于保证所有假设空间可以同时比较。若只让每个假设空间分别以 $1 - \delta$ 的概率估计准确, 算法在看过同一份数据后再从许多假设空间中选, 整体失败概率可能超过 δ 。将第 k 个假设空间的失败概率限制为 δ_k , 并使其总和不超过 δ , 那么至少一个假设空间估计失准的概率就不超过 $\sum_k \delta_k \leq \delta$ 。于是, 以至少 $1 - \delta$ 的概率, 所有假设空间的经验风险与期望风险都满足各自的偏差要求。

定理 4.10 结构风险最小化的期望风险保证 设 $\mathcal{H}_1 \subseteq \mathcal{H}_2 \subseteq \dots$ 是预先给定的非空假设空间, 损失为零一损失, 训练样本 $S \sim \mathcal{P}^n$ 。固定 $\delta \in (0, 1)$, 选择与样本无关的 $\delta_k > 0$, 满足 $\sum_{k \geq 1} \delta_k \leq \delta$ 。假设非负惩罚 $p_k = \text{pen}(k, n, \delta_k)$ 使每个假设空间都满足

$$\mathbb{P}_{S \sim \mathcal{P}^n} \left(\sup_{h \in \mathcal{H}_k} |R_{\mathcal{P}}(h) - \hat{R}_S(h)| > p_k \right) \leq \delta_k. \quad (4.20)$$

这里假定相关事件可测, 且惩罚在观察样本前已经确定。

若学习算法输出 $\hat{h} \in \mathcal{H}_{\hat{k}}$, 并将带惩罚的经验目标求解到给定容差 $\rho \geq 0$, 即

$$\hat{R}_S(\hat{h}) + p_{\hat{k}} \leq \inf_{k \geq 1, h \in \mathcal{H}_k} \{\hat{R}_S(h) + p_k\} + \rho, \quad (4.21)$$

则以至少 $1 - \delta$ 的概率,

$$R_{\mathcal{P}}(\hat{h}) \leq \inf_{k \geq 1} \left\{ \inf_{h \in \mathcal{H}_k} R_{\mathcal{P}}(h) + 2p_k \right\} + \rho. \quad (4.22)$$

精确求解式 (4.19) 时, 取 $\rho = 0$ 。若式 (4.20) 对所有允许分布使用相同的惩罚都成立, 则结论也对这些分布统一成立。

证明. 证明先建立所有假设空间同时估计准确的事件, 再在这个事件上比较算法输出与任意假设。

令 E_k 表示第 k 个假设空间中所有假设都满足 $|R_{\mathcal{P}}(h) - \hat{R}_S(h)| \leq p_k$ 的事件, 并令 $E = \bigcap_{k \geq 1} E_k$ 。至少一个假设空间估计失准的概率不超过各假设空间失准概率之和, 因此

$$\mathbb{P}(E^c) = \mathbb{P}\left(\bigcup_{k \geq 1} E_k^c\right) \leq \sum_{k \geq 1} \mathbb{P}(E_k^c) \leq \sum_{k \geq 1} \delta_k \leq \delta.$$

这个并集界不要求各事件独立; 它们可以由同一份训练样本决定。因而 $\mathbb{P}(E) \geq 1 - \delta$ 。

现在固定一份属于 E 的样本。由于 E 同时控制所有假设空间, 它也控制由数据选出的 $\mathcal{H}_{\hat{k}}$ 及其中的输出 $\hat{h}$ 。于是

$$R_{\mathcal{P}}(\hat{h}) \leq \hat{R}_S(\hat{h}) + p_{\hat{k}}.$$

对任意 k 及任意 $h \in \mathcal{H}_k$, 近似最优性又给出

$$\hat{R}_S(\hat{h}) + p_{\hat{k}} \leq \hat{R}_S(h) + p_k + \rho.$$

同一个事件 E 还保证 $\hat{R}_S(h) \leq R_{\mathcal{P}}(h) + p_k$ 。合并这三次比较, 得到

$$R_{\mathcal{P}}(\hat{h}) \leq R_{\mathcal{P}}(h) + 2p_k + \rho.$$

两个 p_k 的来源不同: 第一个是比较假设所属假设空间时显式加入的惩罚, 第二个用来控制事件 E 上比较假设的经验风险高于期望风险的偏差。这个偏差不等同于前文定义的估计误差; 两项合在一起构成控制假设空间选择所产生估计误差的统计上界。输出假设所属空间的 $p_{\hat{k}}$ 已通过带惩罚目标的比较一并控制。

上式对每个比较假设 $h \in \mathcal{H}_k$ 以及每个 k 都成立, 因此先对 h 、再对 k

取下确界，就得到式 (4.22)。这一步不要求空间内最优假设或最优假设空间实际存在。整个推导在 E 上成立，而该事件的概率至少为 $1 - \delta$ ，故结论成立。 ■

定理右侧允许用每个假设空间的最好期望风险加上统计代价作比较，尽管算法本身不知道这些期望风险。这样的比较常称为**预言机不等式** (oracle inequality)：算法依据可计算的**经验目标**选择假设空间和假设，却能与假想中知道各空间最低期望风险的选择作比较。这里的“预言机”只是比较基准，并不是训练过程能够调用的额外信息。

例如，可以取 $\delta_k = \delta/[k(k+1)]$ ，因为 $1/[k(k+1)] = 1/k - 1/(k+1)$ ，求和恰为 1。若各 $\mathcal{H}_k$ 有限，第 5.2 节的有限假设空间一致收敛界允许取

$$p_k = \sqrt{\frac{\log(2|\mathcal{H}_k|/\delta_k)}{2n}} = \sqrt{\frac{\log(2|\mathcal{H}_k|) + \log(k(k+1)/\delta)}{2n}}.$$

其中 $|\mathcal{H}_k|$ 反映在空间内选择假设的代价， δ_k 的分配还计入同时比较多个假设空间的代价。对于无限假设空间，需要用后面的容量工具另行建立式 (4.20)，不能把无限的假设数直接代入这个有限空间公式。

式 (4.22) 减去贝叶斯风险后，右侧每个比较项都成为相应假设空间的近似误差加上 $2p_k$ ，再加求解容差 ρ 。其中近似误差就是该假设空间的偏差， $2p_k$ 则是控制假设空间选择所产生估计误差的统计项，并不是估计误差的精确值。假设空间太小可能留下较大偏差，过于复杂则通常需要较大的统计项。定理保证算法输出假设的期望风险受这些比较项中最好者控制，并不保证总能达到零期望风险，也没有保证带惩罚目标能够被高效求解。

4.6 本章小结

要判断有限样本能否支持对未来表现的推断，必须先明确学习问题的观测单位、比较空间、算法输出、损失、允许分布族和随机来源。特化到二分类后，学习算法能够直接比较的是样本上的经验风险，需要保证的却是未来数据上的期望风险。PAC 模型把这项要求写成两个明确的目标：输出假设的期望风险或超额期望风险不超过误差容限，训练失败的概率不超过失败概率容限 δ ，也就是成功概率至少达到置信水平 $1 - \delta$ 。可实现设定以零期望风险为基准；不可知设定允许标签噪声与假设空间的表达限制，以空间内期望风险的下确界为基准。两种保证都要求所给样本量适用于全部允许分布。

经验风险最小化并不自动满足这些要求。没有免费的午餐定理说明，若假设空间允许未见输入的标签任意变化，有限观测就不足以可靠预测；增加计算资源不能补足缺失的信息。限制假设空间有助于利用样本，却也可能排除期望风险较低的假设。贝叶斯风险、近似误差与估计误差的分解，

分别说明现有输入信息、假设空间与学习结果对最终期望风险的影响。其中，估计误差比较两个期望风险，不能与经验风险或泛化差混用。

结构风险最小化用经验风险与复杂度惩罚共同选择假设空间。它的保证依赖各空间的经验风险与期望风险偏差能否被控制；下一章将为二分类问题建立这种控制所需的容量条件。即使样本量条件已经成立，能否用可停机、运行时间可接受的程序完成学习，仍是另一项要求。

延伸阅读 Shalev-Shwartz 与 Ben-David 的 *Understanding Machine Learning* 第 2-5 章系统展开了 PAC 模型、经验风险最小化与没有免费的午餐定理，第 7 章进一步讨论结构风险最小化和描述长度。阅读时可以对照本章检查每个结论的比较基准，以及先固定算法、再对分布和样本作保证的量词顺序；这些约定也决定了后续定理应如何解释⁴。

若希望继续区分统计可学习性与程序可计算性，可阅读 Delle Rose 等关于可计算 PAC 学习的研究。其中的有效见证条件说明，统计上知道某种预测不可能出现，与能够写程序找出这种预测，是两项不同的要求。第 5.7 节将给出相应定义与例子⁵。

⁴ S. Shalev-Shwartz, S. Ben-David, *Understanding Machine Learning: From Theory to Algorithms*, Cambridge University Press, 2014, 1st ed.

⁵ V. Delle Rose, A. Kozachinskiy, C. Rojas, T. Steifer, *Find a Witness or Shatter: The Landscape of Computable PAC Learning* In Proceedings of the 36th Conference on Learning Theory, 2023, pp. 511–524

二分类学习的可学习性

第 4 章中，阈值 0.4 和 0.6 对应的假设都分对了四封训练邮件，却对分数为 0.5 的新邮件给出不同答案。增加训练样本有机会区分它们：如果某个假设经常出错，新样本就更容易落在它出错的地方。然而，算法会在观察样本后从整个假设空间中作出选择。某个假设即使经常把新邮件分错，也可能碰巧分对全部训练邮件；只看这批训练结果，算法就无法发现它的问题。如果假设空间中有许多假设，就必须考虑是否有至少一个期望风险较高的假设也碰巧分对了全部训练邮件。因此，要判断需要多少训练邮件，既要计算单个期望风险较高的假设出现这种情况的概率，也要考虑假设空间中有多少假设。

本章从有限假设空间的样本量计算出发，再处理阈值假设空间这样的无限集合。实数阈值虽然有无限多个，在同一组有序输入上却只能形成少数几种预测。VC 维刻画假设空间能在多少个输入上给出全部可能的二元预测；一致收敛把这种表达能力与期望风险联系起来。在此基础上，Rademacher 复杂度与高斯复杂度进一步利用样本信息估计期望风险，样本压缩和集成学习则从算法输出与组合方式建立保证。统计上存在学习器之后，还要检查能否用可停机的程序实现它，以及训练和预测需要多少计算资源。

本章沿用第 4.2 节的二分类设定：观测为输入标签对，采用 i.i.d. 抽样与零一损失，并使用第 4.3 节的可实现与不可知 PAC 量词。这里的变化是分析工具转向 VC 维、Rademacher 复杂度和样本压缩等二分类容量刻画。一般结论默认比较空间为 $\mathcal{H}$ ；集成与可计算学习若允许输出 $\mathcal{H}$ 之外的分类器，会单独声明非恰当输出。

5.1 可实现的有限假设空间

回到邮件过滤的例子。假如算法只能从 0.2、0.4、0.6 和 0.8 这四个阈值中选择，每个阈值对应一个分类假设，假设空间 $\mathcal{H}$ 便只有四个成员。邮件分数仍可取 $[0, 1]$ 中的任意值；有限的是可选假设的数量，而不是邮件分数的取值。知道有哪些假设可选，就能逐个分析它们在样本上全部答对的

可能性。

沿用可实现设定, 假定 $\mathcal{H}$ 中存在期望风险为零的假设 h^* 。随机抽取一封邮件, 它出错的概率为零; 因此它也几乎必然分对样本中的每一封邮件。ERM 选择经验风险最小的假设, 至少可以选到一个经验风险为零的假设。我们称这样的假设与样本**一致** (consistent), 意思是它在这批样本上一次也没有分错。

但是, 分对这批邮件的假设, 面对新邮件时仍可能经常出错。假如一个假设分错随机新邮件的概率为 20%, 那么它分对一封邮件的概率就是 80%; 独立抽取 n 封时, 它碰巧全部分对的概率是 0.8^n 。ERM 只看得到这批样本, 因而可能选中这样的假设。为了保证 ERM 选出的假设期望风险较低, 必须考虑假设空间中是否有任何一个期望风险较高的假设碰巧与样本一致, 而不能只计算其中某个假设的概率。

把 20% 换成一般的误差容限 ε 。设 $Y = \{0, 1\}$ 、 $S \sim \mathcal{P}^n$, 并取一个不随样本改变的假设 $h \in \mathcal{H}$ 。如果它的期望风险 $R_{\mathcal{P}}(h) > \varepsilon$, 随机抽取一封邮件, 它被分对的概率就小于 $1 - \varepsilon$ 。由于样本独立抽取, h 与整批样本一致的概率满足

$$\mathbb{P}(\hat{R}_S(h) = 0) = (1 - R_{\mathcal{P}}(h))^n \leq (1 - \varepsilon)^n \leq e^{-n\varepsilon}. \quad (5.1)$$

ERM 会在看过样本后才决定选哪个假设, 式 (5.1) 不能直接当作 ERM 选错的概率。不过, 如果 ERM 选中了一个与样本一致、期望风险却超过 ε 的假设, $\mathcal{H}$ 中就至少有一个这样的假设分对了整批样本。对 $\mathcal{H}$ 中的假设分别计算这一概率, 再把结果相加, 便得到“至少有一个”的概率上界; 即使几个假设同时分对样本, 这个上界依然成立。由于 $\mathcal{H}$ 只有有限个假设, 我们便能算出使这一概率足够小所需的样本量。

定理 5.1 有限假设空间的可实现 PAC 样本量界 设 $\mathcal{H}$ 有限, $\mathcal{P}$ 对 $\mathcal{H}$ 可实现。若算法输出任意满足 $\hat{R}_S(\hat{h}) = 0$ 的 $\hat{h} \in \mathcal{H}$, 则

$$\mathbb{P}(R_{\mathcal{P}}(\hat{h}) > \varepsilon) \leq |\mathcal{H}|e^{-n\varepsilon}. \quad (5.2)$$

特别地, 只要

$$n \geq \frac{\log |\mathcal{H}| + \log(1/\delta)}{\varepsilon}, \quad (5.3)$$

算法就以至少 $1 - \delta$ 的概率输出期望风险不超过 ε 的假设。

证明. 若输出假设的期望风险大于 ε , 至少有一个期望风险大于 ε 的假设与样本一致。因此

$$\begin{aligned} \mathbb{P}(R_{\mathcal{P}}(\hat{h}) > \varepsilon) &\leq \mathbb{P}(\exists h \in \mathcal{H} : R_{\mathcal{P}}(h) > \varepsilon, \hat{R}_S(h) = 0) \\ &\leq \sum_{h: R_{\mathcal{P}}(h) > \varepsilon} \mathbb{P}(\hat{R}_S(h) = 0) \leq |\mathcal{H}|e^{-n\varepsilon}. \end{aligned}$$

令最后一项不超过 δ 并整理 n , 得到式 (5.3)。 ■

在四个阈值的例子中, $|\mathcal{H}| = 4$ 。如果其中一个阈值对应的假设具有零期望风险, 我们希望 ERM 以至少 99% 的概率选到期望风险不超过 5% 的假设, 就取 $\varepsilon = 0.05$, $\delta = 0.01$ 。式 (5.3) 给出 $\lceil (\log 4 + \log 100)/0.05 \rceil = 120$ 。也就是说, 独立同分布地抽取 120 封训练邮件后, ERM 选出的与样本一致的假设满足上述要求。这个数对所有满足可实现条件的数据分布都适用, 但不表示样本少于 120 封时一定会失败。

如果可选阈值从 4 个增加到 8 个, 保持 5% 的期望风险要求和 99% 的成功概率不变, 公式给出的充分样本量只从 120 封增至 $\lceil (\log 8 + \log 100)/0.05 \rceil = 134$ 封。一般地, 假设数翻倍, 式中尚未取整的样本量只增加 $\log 2/\varepsilon$ 。因此, 有限假设空间在可实现设定下是 PAC 可学习的: 对任意给定的 ε 和 δ , 都能找到一个不依赖具体数据分布的充分样本量。这里保证的是样本数量; 能否高效地找到假设, 还要另行分析。

这段推导依赖可实现设定: 至少有一个假设能把样本全部分对。样本足够多时, 期望风险较高的假设也全部分对的机会就很小, ERM 因而不容易选中它。标签有噪声时, 所有假设都可能在样本上出错, ERM 只能比较它们各自错了多少。一个面对新邮件时经常出错的假设, 可能恰好在这批样本上错得很少。怎样判断样本上的比较在新邮件上仍然可靠?

5.2 不可知的有限假设空间

ERM 看过样本后才选择经验风险最小的假设。某个假设即使面对新邮件时经常出错, 也可能碰巧在这批样本上少犯错, 从而被 ERM 选中。一种保证比较可靠的办法, 是让同一批样本上所有假设的经验风险, 都与各自的期望风险相差很小。这项要求称为一致收敛。有限假设空间允许我们直接证明这项性质, 并据此分析不可知设定下的 ERM; 无限假设空间能否满足同样的要求, 则留到第 5.3 节讨论。

设想我们先定好一个阈值, 再抽取训练邮件。这个阈值对应的假设 h 不会随样本改变。它分错随机新邮件的概率是期望风险 $R_{\mathcal{P}}(h)$, 在 n 封样本邮件中分错的比例则是经验风险 $\hat{R}_S(h)$ 。换一批邮件, 它的经验风险可能变化。那它与期望风险相差超过 η 的概率有多大? 对每封样本邮件, $\ell_{01}(h(x_i), y_i)$ 取 0 或 1, 表示 h 是否分错。由于样本邮件是独立抽取, 这些随机变量相互独立, 均值都是 $R_{\mathcal{P}}(h)$ 。Hoeffding 不等式给出

$$\mathbb{P}(|\hat{R}_S(h) - R_{\mathcal{P}}(h)| > \eta) \leq 2e^{-2n\eta^2}. \quad (5.4)$$

式 (5.4) 只控制抽样前定好的 h , 不能直接套在随样本改变的 ERM 输出 $A(S)$ 上。例如, 用同一批带标签的邮件分别检验四个阈值, 我们可以算出这四个假设的经验风险, ERM 选择其中经验风险最小的假设。若四个经

验风险与各自的期望风险都相差不超过 η ，那么所选假设的期望风险至多比四者中的最低期望风险高 2η 。其中一份 η 来自对所选假设的估计，另一份来自对最佳比较假设的估计；后面的定理将逐步证明这一点。假设数量增加后，同样可以通过控制所有假设的估计偏差，保证选出的假设不会离最佳比较假设太远。图 5.1 用竖线连接每个假设的经验风险与期望风险；如果每条线都短，看过样本后才选出的假设也会受到保证。




图 5.1 固定一个假设与同时考察全部假设的区别。即使某个假设的经验风险接近其期望风险，ERM 仍可能选中其他估计偏差较大的假设。若全部竖线都短，框中由样本选出的假设也有保证。

图中的每条竖线都短，意味着没有哪个假设的经验风险明显偏离期望风险。以四个阈值为例，设可接受的风险差为 η ：只有四个阈值各自的经验风险与期望风险都相差不超过 η ，这批邮件才满足“同时接近”。我们希望找到一个邮件数，使独立抽取这么多带标签邮件时，出现这种情形的概率至少为 $1 - \delta$ ；这里 δ 是允许的失败概率。而且，这个邮件数不能随邮件与标签的分布改变。下面将这一要求写成正式定义。

可测性与可分性约定 有限假设空间中的上确界只是有限个可测随机变量的最大值，不会产生额外的可测性问题。处理无限类时，本章对损失类

$$\mathcal{F}_{01} = \{(x, y) \mapsto \ell_{01}(h(x), y) : h \in \mathcal{H}\}$$

采用第 4.1 节的可测性与可分性约定。压缩、重构和学习器输出涉及的数据依赖映射也须可测；可实现的零一损失样本可选择与样本一致的成员，其他存在性证明则使用该约定中的可测近似 ERM。若这些条件不成立，本章结论不能无条件外推。

定义 5.2 一致收敛 设 $\mathcal{H}$ 是由可测函数 $h : X \rightarrow \{0, 1\}$ 组成的非空假设空间，采用零一损失并满足第 4.1 节的可测性与可分性约定。如

果对任意 $\eta, \delta \in (0, 1)$, 都存在只依赖 η, δ 和 $\mathcal{H}$ 的正整数 $m_{\mathcal{H}}^{\text{UC}}(\eta, \delta)$, 使得对任意定义在 $X \times \{0, 1\}$ 上的联合分布 $\mathcal{P}$ 及任意 $n \geq m_{\mathcal{H}}^{\text{UC}}(\eta, \delta)$, 独立同分布样本 $S \sim \mathcal{P}^n$ 满足

$$\mathbb{P}_{S \sim \mathcal{P}^n} \left(\sup_{h \in \mathcal{H}} |\hat{R}_S(h) - R_{\mathcal{P}}(h)| \leq \eta \right) \geq 1 - \delta, \quad (5.5)$$

就称 $\mathcal{H}$ 满足**一致收敛** (uniform convergence)。

式 (5.5) 中的上确界检查 $\mathcal{H}$ 内全部假设的估计偏差。它不超过 η , 表示这一批样本对每个假设都估得准。即使最大偏差没有被某个假设取到, 上确界仍然给出这些偏差的最小上界。概率是对整批样本的随机抽取而言, 不要求每一批样本都符合条件。这里 $\mathcal{P}$ 同时规定输入 x 出现的频率以及给定输入时标签 y 如何产生, 并非只指输入的边缘分布 $\mathcal{P}_X$ 。不同分布可以改变各假设的期望风险, 但不能改变保证所需的样本量 $m_{\mathcal{H}}^{\text{UC}}(\eta, \delta)$ 。定义也不要求 $\mathcal{H}$ 中存在零期望风险假设, 因此适用于不可知设定; 它的分布无关要求与定义 4.4 相同。

一致收敛保证的是估计准确, 并不要求所有假设的期望风险都低: 期望风险高的假设只要经验风险也高, 仍符合要求。

对有限假设空间, 所有假设的经验风险同时接近期望风险, 等价于没有任何假设的风险差超过 η 。式 (5.4) 给出了每个固定假设出现较大偏差的概率上界。有限个假设的这些概率相加, 便能控制是否有任何一个假设估计失准。

定理 5.3 有限假设空间的一致收敛样本量界 设非空假设空间 $\mathcal{H}$ 有限, $\mathcal{P}$ 是任意输入与标签的联合分布, $S \sim \mathcal{P}^n$ 。对任意 $\eta, \delta \in (0, 1)$, 只要样本量满足

$$n \geq \frac{\log(2|\mathcal{H}|/\delta)}{2\eta^2}, \quad (5.6)$$

就有

$$\mathbb{P}_{S \sim \mathcal{P}^n} \left(\sup_{h \in \mathcal{H}} |\hat{R}_S(h) - R_{\mathcal{P}}(h)| \leq \eta \right) \geq 1 - \delta.$$

同一概率界也可写为: 对任意 $n \geq 1$ 和 $\delta \in (0, 1)$, 以下不等式以至少 $1 - \delta$ 的概率成立:

$$\sup_{h \in \mathcal{H}} |\hat{R}_S(h) - R_{\mathcal{P}}(h)| \leq \sqrt{\frac{\log(2|\mathcal{H}|/\delta)}{2n}}. \quad (5.7)$$

因此, 有限假设空间满足定义 5.2 中的一致收敛。

证明. 对每个固定的 $h \in \mathcal{H}$, 式 (5.4) 给出 $|\hat{R}_S(h) - R_{\mathcal{P}}(h)| > \eta$ 的概率上界。

只要其中一个假设发生这种偏差，上确界就会超过 η ；把至多 $|\mathcal{H}|$ 个概率相加，可得

$$\mathbb{P}\left(\sup_{h \in \mathcal{H}} |\hat{R}_S(h) - R_{\mathcal{P}}(h)| > \eta\right) \leq 2|\mathcal{H}|e^{-2n\eta^2}.$$

若 n 满足式 (5.6)，右侧至多为 δ 。反过来，令右侧等于 δ 并解出 η ，得到式 (5.7)。两个界都对任意 $\mathcal{P}$ 成立，所需样本量不依赖 $\mathcal{P}$ 。 ■

一致收敛保证同一份样本能准确比较所有假设的风险。ERM 输出 $\hat{h}$ 的经验风险不高于任意比较假设 $h \in \mathcal{H}$ 的经验风险；若两者的经验风险都接近各自的期望风险，便能将样本上的比较转成期望风险的比较。下面直接给出有限假设空间所需的样本量。

定理 5.4 有限假设空间的不可知 PAC 样本量界 设非空假设空间 $\mathcal{H}$ 有限， $\mathcal{P}$ 是任意输入与标签的联合分布， $S \sim \mathcal{P}^n$ ， $\hat{h}$ 是 $\mathcal{H}$ 上的精确 ERM。对任意 $\varepsilon, \delta \in (0, 1)$ ，只要

$$n \geq \frac{2}{\varepsilon^2} \left(\log(2|\mathcal{H}|) + \log \frac{1}{\delta} \right), \quad (5.8)$$

就有

$$\mathbb{P}_{S \sim \mathcal{P}^n} \left(R_{\mathcal{P}}(\hat{h}) \leq \inf_{h \in \mathcal{H}} R_{\mathcal{P}}(h) + \varepsilon \right) \geq 1 - \delta.$$

证明. 在定理 5.3 中取 $\eta = \varepsilon/2$ 。式 (5.8) 保证 $\sup_{h \in \mathcal{H}} |\hat{R}_S(h) - R_{\mathcal{P}}(h)| \leq \varepsilon/2$ 以至少 $1 - \delta$ 的概率成立。固定一份满足这一条件的样本，任取 $h \in \mathcal{H}$ 。ERM 输出的 $\hat{h}$ 也属于 $\mathcal{H}$ ，所以两者的经验风险与期望风险都相差不超过 $\varepsilon/2$ 。由 ERM 的选择规则， $\hat{R}_S(\hat{h}) \leq \hat{R}_S(h)$ ，于是

$$\begin{aligned} R_{\mathcal{P}}(\hat{h}) &\leq \hat{R}_S(\hat{h}) + \frac{\varepsilon}{2} \\ &\leq \hat{R}_S(h) + \frac{\varepsilon}{2} \\ &\leq R_{\mathcal{P}}(h) + \varepsilon. \end{aligned}$$

第一步和第三步分别使用输出假设与比较假设的风险估计，第二步使用 ERM 的选择规则。这个不等式对每个 $h \in \mathcal{H}$ 都成立，对右侧取下确界即得定理结论。 ■

这里的目标是让输出假设比假设空间内最低期望风险至多高 ε 。与可实现设定的式 (5.3) 相比，充分界对误差容限的依赖从 $1/\varepsilon$ 变为 $1/\varepsilon^2$ 。在可实现设定下，假设空间中有一个期望风险为零的假设，它几乎必然分对全部训练样本；只需防止期望风险超过 ε 的假设也碰巧全部分对。在不可知设定下，假设可能都在训练样本上犯错，ERM 必须比较错误比例的大小。因

此，我们要求每个假设的经验风险都接近其期望风险，而式 (5.4) 中这种估计偏差的概率随 $n\eta^2$ 增大而下降，这便产生了上面的 $1/\varepsilon^2$ 充分界。

同一个界也为定理 4.10 中的复杂度惩罚提供了具体形式。设 $\mathcal{H}_1 \subseteq \mathcal{H}_2 \subseteq \dots$ 是预先给定的一列有限假设空间，其中 k 表示第几个空间。结构风险最小化会根据样本选择 k 和 $h \in \mathcal{H}_k$ 。如果只控制某个预先指定的 $\mathcal{H}_k$ 中的估计偏差，算法仍可能选中另一个空间：那个空间中某些假设的经验风险恰好低于期望风险，因而看起来特别好。因此，我们需要控制同一份样本对每个 $\mathcal{H}_k$ 中所有假设的估计偏差。

具体地，在抽样前选定 $\delta_k > 0$ ，使 $\sum_k \delta_k \leq \delta$ 。第 k 个空间允许的估计偏差记为

$$p_k = \sqrt{\frac{\log(2|\mathcal{H}_k|/\delta_k)}{2n}}.$$

式 (5.7) 保证：对单独一个 $\mathcal{H}_k$ ，其中某个假设满足 $|\hat{R}_S(h) - R_{\mathcal{P}}(h)| > p_k$ 的概率至多为 δ_k 。把各空间的这些失败概率相加，可知至少以 $1 - \delta$ 的概率，同一份样本满足

$$|\hat{R}_S(h) - R_{\mathcal{P}}(h)| \leq p_k \quad (k \geq 1, h \in \mathcal{H}_k).$$

这个不等式对每个空间中的每个假设同时成立。无论算法后来选中哪个 (k, h) ，其期望风险都不超过经验风险加上对应的 p_k 。因此，结构风险最小化可以选择使

$$\hat{R}_S(h) + p_k \tag{5.9}$$

最小的 (k, h) 。空间越大，或者分配给它的 δ_k 越小， p_k 就越大。例如，取 $\delta_k = \delta/[k(k+1)]$ 时，因 $1/[k(k+1)] = 1/k - 1/(k+1)$ ，所有 δ_k 之和恰为 δ ；这是一种无需额外选择规则的分配方法。

另一种分配方法可以把事先选定的空间描述长度写进惩罚项。这里要描述的只是序列中选择了哪个 $\mathcal{H}_k$ ，也就是它的序号 k 。我们可以预先给每个序号一个二进制编码，并要求没有任何编码是另一编码的开头，这称为前缀编码。例如，0、10、11 可以分别标识三个空间。任取有限组编码，并考察比它们都长的二进制串：以某个 L_k 位编码开头的串占同长度串的 2^{-L_k} ，不同前缀编码对应的串又互不重叠。因此，这组编码的 2^{-L_k} 之和不超过 1；任意有限组都如此，全部编码也满足 $\sum_k 2^{-L_k} \leq 1$ ，所以取 $\delta_k = \delta 2^{-L_k}$ 仍满足总失败概率的要求。此时 $\log(1/\delta_k) = \log(1/\delta) + L_k \log 2$ ：较长的编码通过较小的 δ_k 增大对应的 p_k 。前缀编码的作用是提供一种有效的失败概率分配，并使选择空间所需的编码长度成为惩罚的一部分；前面的 PAC 保证本身不要求使用这种编码。

5.3 无限假设空间

有限假设空间中，我们分别计算每个假设的经验风险与期望风险相差超过容限的概率，再把这些概率相加，得到式(5.6)的一致收敛样本量界。如果假设空间无限，直接按假设个数相加便无法得到这样的上界。要判断无限假设空间能否一致收敛，需要换一种方式衡量它的预测能力：考察同一组有限输入上，空间内的假设能给出多少种不同答案。

5.3.1 打散和 VC 维

以实数阈值为例。阈值可以取无限多个值，但对分数分别为 0.3 和 0.7 的两封邮件，预测只可能是 (1, 1)、(0, 1) 或 (0, 0)。阈值不超过 0.3 时，两封都被预测为 1；阈值满足 $0.3 < t \leq 0.7$ 时，只有较高分数的邮件被预测为 1；阈值高于 0.7 时，两封都被预测为 0。虽然两个不同阈值在其他邮件上的判断可能不同，只要它们对这两封邮件给出相同答案，这里就把它算作同一组。预测 (1, 0) 不会出现：较低分数达到阈值时，较高分数也一定达到阈值。

对一般情形，固定 m 个互异输入 $C = \{x_1, \dots, x_m\}$ 。我们按照假设在 C 上的预测分组：若两个假设对这 m 个输入逐一给出相同标签，就把它放在同一组。各组对应的不同标签向量构成

$$\mathcal{H}|_C = \{(h(x_1), \dots, h(x_m)) : h \in \mathcal{H}\}. \quad (5.10)$$

这个集合称为 $\mathcal{H}$ 在 C 上的**限制** (restriction)。无论 $\mathcal{H}$ 有多少假设， m 个输入上最多只有 2^m 种不同预测，因此分组数总是有限。但“有限”还不足以保证一致收敛。为了衡量假设空间在这组输入上能给出多少种不同预测，我们把 $\mathcal{H}|_C$ 与全部 2^m 种二元预测组成的集合 $\{0, 1\}^m$ 比较。如果两者相等，意味着无论怎样给这 m 个输入标注 0 或 1，都能从假设空间中找到一个在这些输入上逐一给出相同标签的假设。这种性质称为打散。

定义 5.5 打散 设 $\mathcal{H}$ 是输入空间 X 上的二分类假设空间， $C = \{x_1, \dots, x_m\} \subseteq X$ 由 m 个互异输入组成。如果对任意 $(b_1, \dots, b_m) \in \{0, 1\}^m$ ，都存在 $h \in \mathcal{H}$ ，使得 $h(x_i) = b_i$ 对所有 $i = 1, \dots, m$ 成立，则称 $\mathcal{H}$ **打散** (shatter) C 。等价地，

$$\mathcal{H}|_C = \{0, 1\}^m.$$

阈值类与区间类的逐模式比较已经放在第一卷“数学准备”的“计数与计算”章。该例固定 $x_1 < x_2$ ，展示阈值假设缺少 (1, 0)，而区间假设能够分别实现四种标签；每种模式可以由不同假设见证，不要求一个假设同时实现全部模式。

图中只检验了两个输入上的四种可能预测。若把输入增加到三个，可能预测就变成八种；能打散两个点的假设空间，未必还能打散三个点。要比较不同假设空间的这种能力，可以继续增加点数，考察是否存在一组点，使空间内的假设能够给出这组点上的所有二元预测。这里要求找到一组符合条件的输入，而不是要求同样大小的每一组输入都能被打散。VC 维用可被打散的点集规模的上限，概括假设空间的这种能力。

定义 5.6 VC 维 设 $\mathcal{H}$ 是输入空间 X 上的非空二分类假设空间。 $\mathcal{H}$ 的 VC 维 (Vapnik-Chervonenkis dimension) 定义为

$$VC(\mathcal{H}) = \sup\{|C| : C \subseteq X, |C| < \infty, \mathcal{H}|_C = \{0, 1\}^{|C|}\}.$$

若可被打散的有限点集的大小没有上界，则 VC 维为无穷；若没有单点能被打散，则 VC 维为零。

前面讨论的阈值和区间可以帮助我们理解如何确定 VC 维。对一维阈值 $h_t(x) = \mathbb{I}\{x \geq t\}$ ，固定一个输入 x_1 。取 $t \leq x_1$ 时， x_1 的预测为 1；取 $t > x_1$ 时，预测为 0。因此，一个点的两种标签都能实现。但任取 $x_1 < x_2$ ，如果阈值让 x_1 得到 1，就有 $t \leq x_1 < x_2$ ， x_2 也必然得到 1。两个点上的 (1, 0) 总是无法实现，所以阈值假设空间的 VC 维为 1。

现在改用单区间假设 $h_{a,b}(x) = \mathbb{I}\{a \leq x \leq b\}$ ，其中 $a \leq b$ 。对任意两个不同点，可以选择避开两点、只覆盖其中一点或同时覆盖两点的区间，从而实现全部四种预测，VC 维至少为 2；第一卷的对照图已逐行列出这些模式。再任取 $x_1 < x_2 < x_3$ 。若希望标签为 (1, 0, 1)，区间必须同时包含 x_1 和 x_3 ，于是也包含中间的 x_2 ，与所需标签 0 矛盾。因此，没有三个点能被单区间假设空间打散，其 VC 维恰好为 2。第一卷的同一对照图把“找到可打散点集”的下界见证与“多一个点时存在无法实现模式”的上界见证并排展示；这里保留计算结论，用于下面的样本复杂度推导。

在平面上，仿射半空间就是直线的一侧。三个不共线的点能被直线打散：全同标签时，把直线放在三点之外；标签不全相同时，用直线把一个顶点与另外两个顶点分开，并选择哪一侧预测 1。任意四个点则总有一种无法实现的二元预测。若其中三个点共线，就把它们从左到右标为 (1, 0, 1)；若四点构成凸四边形，就给两组对角点赋予相反标签；若一点在其余三点组成的三角形内部，就把内部点标为 1、其余三点标为 0。在后两种情形中，两类点的凸包相交，直线不能把它们分开。因此，平面仿射半空间的 VC 维为 3。一般地， $\mathbb{R}^d$ 中的仿射半空间 $\mathbb{I}\{\mathbf{w}^\top \mathbf{x} + b \geq 0\}$ 的 VC 维为 $d + 1$ ： $d + 1$ 个仿射无关点给出下界，Radon 定理保证任意 $d + 2$ 个点都能分成凸包相交的两组，从而给出上界。

这几个例子采用同一判断方法：先找到一组能被打散的点，确定 VC 维的下界；再证明每组多一个点的输入都存在无法实现的二元预测，确定上

界。

5.3.2 生长函数和 Sauer-Shelah 引理

VC 维告诉我们，是否存在一组 m 个输入，使假设空间能在其上给出全部 2^m 种预测。若 m 超过 VC 维，答案是否定的，却仍不知道假设空间还能给出多少种预测。学习算法会根据样本选择假设；要分析这种选择，需要数清：在 m 个输入上，空间内的假设最多能给出多少个不同的预测向量。**生长函数** (growth function) 记录这个最大数目随输入数 m 的变化；即使假设空间无限，同一组输入上预测完全相同的假设也只计一次。

定义 5.7 生长函数 对二分类假设空间 $\mathcal{H}$ 及整数 $m \geq 0$ ，其生长函数记为 $\Pi_{\mathcal{H}}(m)$ ，定义为

$$\Pi_{\mathcal{H}}(m) = \max_{x_1, \dots, x_m \in X} |\{(h(x_1), \dots, h(x_m)) : h \in \mathcal{H}\}|. \quad (5.11)$$

最大值遍历 m 个输入的各种选法，因此生长函数反映假设空间能达到的最多预测数目，不依赖某一批碰巧抽到的输入。当 $m = 0$ 时只有一个空预测向量，故 $\Pi_{\mathcal{H}}(0) = 1$ 。

刚才用于计算 VC 维的三个假设空间，也可以用来观察预测数目如何增长。对递增阈值，把 m 个不同输入从小到大排列，预测只能是左侧连续的 0 和右侧连续的 1。阈值可以放在第一个输入之前、任意两个相邻输入之间，或最后一个输入之后，共 $m + 1$ 个位置，因此 $\Pi_{\mathcal{H}}(m) = m + 1$ 。例如三个输入只能得到 (0, 0, 0)、(0, 0, 1)、(0, 1, 1) 和 (1, 1, 1) 四种预测；每增加一个输入，最多只多出一种新的预测。

对单区间假设，预测为 1 的输入必须在排序后连成一段。若一个输入也不覆盖，得到全 0；若覆盖输入，就选出这段连续输入的起点和终点。长度为 1、2、...、 m 的连续段分别有 $m, m-1, \dots, 1$ 个，合计 $m(m+1)/2$ 个，因此 $\Pi_{\mathcal{H}}(m) = 1 + m(m+1)/2$ 。三个输入时有七种预测，唯一缺少的是 (1, 0, 1)；输入继续增多时，可能的连续段数按 m^2 的量级增长。

平面仿射半空间允许分界直线转动，预测数又有所不同。把 $m \geq 3$ 个输入放在凸多边形的顶点上：直线选出的正类顶点沿多边形边界连续排列。除全 0 和全 1 外，可以从 m 个顶点中选一个作为这段正类的起点，再选 1 到 $m-1$ 中的一个作为长度，得到 $m(m-1)$ 种预测。直线分割的计数结果表明，这已经是任意 m 个平面输入上的最大数目，故 $\Pi_{\mathcal{H}}(m) = m(m-1) + 2$ ($m \geq 1$)¹。例如四个顶点共有 16 种二元预测，直线能实现其中 14 种；沿边界交替出现的 (1, 0, 1, 0) 及 (0, 1, 0, 1) 无法实现。

输入数同为四个时，阈值、单区间和平面仿射半空间最多分别给出 5、11、14 种预测，而不受限制的多元预测共有 16 种。这三个空间的 VC 维分

¹ T. M. Cover, *Geometrical and Statistical Properties of Systems of Linear Inequalities with Applications in Pattern Recognition* In IEEE Transactions on Electronic Computers, 1965, vol. EC-14, no. 3, pp. 326–334

别为 1、2 和 3，预测数目却分别按 m 、 m^2 和 m^2 的量级增长。VC 维不决定生长函数的精确值，但能约束它增长得有多快：若 VC 维为 d ，在 $m \leq d$ 时可以找到一组输入得到全部 2^m 种预测；超过 d 后，任何一组输入都不再能得到全部预测。更重要的是，增加一个输入时，原有预测中能分别接上 0 和 1 的数量也受到限制，否则就可能打散 $d+1$ 个点。Sauer-Shelah 引理把这种限制写成对有限 VC 维的二分类假设空间适用的预测数目上界。

引理 5.8 Sauer-Shelah 引理 若 $1 \leq d = \text{VC}(\mathcal{H}) < \infty$ ，则对 $m \geq d$ ，

$$\Pi_{\mathcal{H}}(m) \leq \sum_{j=0}^d \binom{m}{j} \leq \left(\frac{em}{d}\right)^d. \quad (5.12)$$

证明. 证明对 m 归纳：没有输入时，只有一个空预测向量；VC 维为零的非空假设空间在任意一组输入上也只能给出一种预测。这些情形构成归纳起点。固定任意 m 个互异输入，并暂时删去最后一个输入的预测。前 $m-1$ 个输入上的每种预测至少有一种扩展；有些预测还能分别接上 0 和 1，因此在总数中多贡献一次。由归纳假设，删去最后一位后不同预测至多有 $\sum_{j=0}^d \binom{m-1}{j}$ 种。把能同时接上 0 和 1 的旧预测单独收集起来，视为前 $m-1$ 个输入上的一个新假设空间。它的 VC 维至多为 $d-1$ ：否则可以从前 $m-1$ 个输入中选出 d 个可被它打散的点，再加入最后一个输入，就会有 $d+1$ 个点被原假设空间打散，与前提矛盾。这些双向扩展的预测至多有 $\sum_{j=0}^{d-1} \binom{m-1}{j}$ 种。两项相加，再用 Pascal 恒等式 $\binom{m-1}{j} + \binom{m-1}{j-1} = \binom{m}{j}$ ，得到第一道不等式。

第二道不等式只把组合数写成便于代入样本界的形式。令 $a = d/m \leq 1$ ，则对 $j \leq d$ 有 $a^j \geq a^d$ ，于是

$$a^d \sum_{j=0}^d \binom{m}{j} \leq \sum_{j=0}^d \binom{m}{j} a^j \leq (1+a)^m \leq e^{ma} = e^d.$$

两边除以 a^d 即得结论。若 $d=0$ ，非空假设空间在每个点上的标签都唯一，生长函数恒为 1，无需使用含有 d 作为分母的表达式。 ■

当 d 固定时，引理右侧随 m 至多按 m^d 的量级增长，而全部二元预测的数目是 2^m 。这说明有限 VC 维足以阻止生长函数一直按指数速度增长；实际增长仍可能比引理的上界更慢，如 VC 维为 3 的平面仿射半空间就只按 m^2 的量级增长。

第一卷“数学准备”的“计数与计算”章还在同一对数坐标中比较了全部 2^m 种标签组合与有限 VC 维带来的多项式计数。曲线间不断增大的差距表示可实现模式在全部二元组合中所占比例持续缩小，并不要求假设空间本身只有有限多个函数。

5.3.3 二分类可学习性基本定理

我们希望建立经验风险与期望风险之间的关系：算法在样本上找到经验风险较小的假设后，需要保证这个假设的期望风险也足够小。前面的一致收敛分析表明，只要同一份样本上所有假设的经验风险与各自的期望风险都足够接近，ERM 就能得到这样的保证。对于无限假设空间，接下来要说明生长函数如何帮助我们控制这些差值。

期望风险取决于未知的数据分布，无法直接计算。为分析它与经验风险的差，我们在证明中引入另一份样本 $S' = (z'_1, \dots, z'_n)$ ：它与原样本 $S = (z_1, \dots, z_n)$ 相互独立，每个观测都来自同一个输入与标签的联合分布 $\mathcal{P}$ ，其中 $z_i = (x_i, y_i)$ 。这份**副样本**（ghost sample）只用于理论分析，学习算法不需要实际取得它。

给定原样本 S 并选定一个假设 h 后，可以在副样本上重新计算它的经验风险 $\hat{R}_{S'}(h)$ 。由于副样本没有参与选择 h ，它能独立评估这个假设的预测错误率；对副样本的所有可能抽样结果取平均，便得到 $R_{\mathcal{P}}(h)$ 。如果 $\hat{R}_S(h)$ 与 $R_{\mathcal{P}}(h)$ 相差很大，而 $\hat{R}_{S'}(h)$ 接近 $R_{\mathcal{P}}(h)$ ，那么两份样本上的经验风险也会相差较大。因此，通过控制两份样本上经验风险的差，可以间接控制原样本的经验风险与期望风险的差。这里并不要求副样本已经能同时准确评估所有假设；证明只需对原样本确定后选出的一个假设使用独立抽样的估计，再将两种偏差事件的概率联系起来。

两份样本的比较只涉及 $2n$ 个观测，这就使生长函数能够发挥作用。在这些输入上，给出完全相同预测的假设，在两份样本上的经验风险也完全相同。因此，即使假设有无限多个，需要区分的预测结果也至多有 $\Pi_{\mathcal{H}}(2n)$ 种。接着，将每对观测 (z_i, z'_i) 以相同概率保持原位或相互交换，各对独立进行。两份样本独立同分布，所以这种交换不改变样本的联合分布；对一种固定的预测结果，交换只会随机改变每对观测对经验风险差值的贡献的正负号。由此可以用集中不等式控制这一差值较大的概率，再把至多 $\Pi_{\mathcal{H}}(2n)$ 种预测结果对应的概率相加，得到存在任意一个假设使差值过大的概率上界。引入副样本并进行这种随机交换，构成了**对称化**（symmetrization）分析。

当 VC 维 d 有限时，Sauer-Shelah 引理给出 $\Pi_{\mathcal{H}}(2n) \leq (2en/d)^d$ ($1 \leq d \leq 2n$)。这说明需要比较的预测数目至多随样本量按多项式增长，而集中不等式给出的单项偏差概率随样本量指数下降。结合这两个结论，可得某个普适常数 $C > 0$ ，使

$$\sup_{h \in \mathcal{H}} |R_{\mathcal{P}}(h) - \hat{R}_S(h)| \leq C \sqrt{\frac{d \log(2en/d) + \log(1/\delta)}{n}} \quad (5.13)$$

在 $1 \leq d \leq n$ 时以至少 $1 - \delta$ 的概率成立。这里 d 表示 VC 维， C 与假设空

间、分布及样本量无关；当 $n < d$ 时仍可使用经验风险与期望风险的差不超过 1 的平凡界。固定有限的 d 和失败概率容限 δ 后，右侧随 n 增大趋于零。因此，只要样本量足够大，就能以至少 $1 - \delta$ 的概率，使所有假设的经验风险与各自的期望风险之差都不超过指定的误差容限。同一个样本量要求适用于所有允许的联合分布 $\mathcal{P}$ ，这就得到了一致收敛。

由前面 ERM 的分析，一致收敛进一步保证不可知 PAC 可学习。反过来，若 VC 维无限，没有免费的午餐定理会排除分布无关的 PAC 学习保证。由此，VC 维、一致收敛与 PAC 可学习性之间形成了下面的等价关系。式 (5.13) 足以证明这种等价关系，但其中的对数因子不一定是最优样本复杂度所必需的。

定理 5.9 二分类学习基本定理 在二分类、零一损失、独立同分布抽样、分布无关且满足共享可测性约定的设定中，对非空假设空间 $\mathcal{H}$ ，下列命题等价：

1. $\mathcal{H}$ 是不可知 PAC 可学习的；
2. $\mathcal{H}$ 是可实现 PAC 可学习的；
3. $\mathcal{H}$ 满足一致收敛；
4. $VC(\mathcal{H}) < \infty$ 。

若 $d = VC(\mathcal{H}) \geq 2$ ，在误差容限和失败概率容限均小于固定常数的范围内，允许非恰当学习时，可实现学习的最优样本复杂度阶为 $(d + \log(1/\delta))/\varepsilon$ ，不可知学习的阶为 $(d + \log(1/\delta))/\varepsilon^2$ ；上述阶数表达略去了普适常数。

证明. 若 VC 维有限，Sauer–Shelah 引理限制合并样本上的不同预测数；对称化把这种计数变成式 (5.13) 的一致收敛界。在一致收敛事件上，ERM 输出与任意比较假设的经验风险之差不大于零，而两者的经验风险与期望风险各相差至多 η ，因此输出假设的期望风险至多比 $\inf_{h \in \mathcal{H}} R_{\mathcal{P}}(h)$ 高 2η 。令 $\eta = \varepsilon/2$ ，便得到不可知 PAC 可学习；不可知保证覆盖可实现分布，因而也推出可实现 PAC 可学习。

反过来，若 VC 维无限，对任意样本量 n 都能找到至少 $2n$ 个可被 $\mathcal{H}$ 打散的输入。对任意给定的算法，第 4.4.2 节的没有免费的午餐定理都能在这些输入上构造一个可实现分布，使该算法只用 n 个观测时，以不低于某个正常数的概率输出期望风险超过固定误差阈值的假设。这与可实现 PAC 要求的统一样本量矛盾。因此，可实现 PAC 可学习必然要求 VC 维有限。两条方向合起来得到四个命题的等价性。关于最优样本复杂度阶的上下界需要比上述等价性证明更精细的工具；这里不将它们归因于式 (5.13)。 ■

这个定理把第4章的 PAC 定义变成一个可检查的容量条件。它说的是是否存在分布无关的学习保证；样本量是否达到最优阶，是另一项更细的要求。

经典生长函数证明给出的可实现上界比定理所列最优阶多出 $\log(1/\epsilon)$ 。更精细的学习器和分析可以去掉这项；Hanneke 给出了达到可实现最优阶的构造²。因此，最优阶不表示任意 ERM 都达到同样的样本量，也不表示要求输出属于 $\mathcal{H}$ 时总能达到该阶。维度为 0 或 1 的边界情形需要另行分析。这个统计结论也没有说明 ERM 是否容易计算；计算问题将在本章末尾单独讨论。

²S. Hanneke, *The Optimal Sample Complexity of PAC Learning* In *Journal of Machine Learning Research*, 2016, vol. 17, no. 38, pp. 1–15

5.4 估计期望风险

上一节利用 VC 维回答了二分类假设空间是否具有分布无关 PAC 可学习性。接下来，我们关心一个更具体的问题：算法已经根据样本选出了一个假设，它在未来数据上的期望风险最多有多大？经验风险可以由已有样本计算，而期望风险依赖未知的数据分布，因此还需要估计两者之间可能存在的差距。

VC 维给出的一致收敛结论也能用于估计这个差距，但它依据整个输入空间的打散能力，没有直接利用当前样本的位置以及实值预测和损失的大小。本节介绍 Rademacher 复杂度和高斯复杂度，用这些信息进一步分析期望风险。所得结论具有共同形式：在可计算的期望风险上，加上复杂度项和抽样误差项，得到一个以高概率成立的期望风险上界。这里的“估计”指给出这样的上界，并不意味着能够从有限样本精确算出未知的期望风险。

5.4.1 Rademacher 复杂度

Rademacher 复杂度（Rademacher complexity）衡量函数空间在一批固定样本上适应随机正负号的能力。这里的正负号独立于数据的真实标签，只是分析中引入的随机系数。如果函数空间可以灵活地调整各个样本点上的函数值，就更容易让正号对应较大的值、负号对应较小的值，从而得到较大的加权和。

这些随机正负号来自上一节的对称化证明。交换原样本与副样本中的一对观测，会改变这对观测对经验风险差值的贡献的正负号。因此，我们需要控制的是：允许从整个函数空间选择函数时，这些带随机符号的函数值相加后能有多大。

例如，固定三个观测 z_1, z_2, z_3 ，随机符号取到 $(1, -1, 1)$ 时，函数 f 的得分为 $[f(z_1) - f(z_2) + f(z_3)]/3$ 。大的 $f(z_1), f(z_3)$ 和小的 $f(z_2)$ 都会提高得分。每次重新抽取符号，都允许从函数空间重新选择得分最高的函数；这

些最高得分的平均值，就是下面定义的经验 Rademacher 复杂度。

定义 5.10 经验 Rademacher 复杂度 设 $\mathcal{G}$ 为 $Z \rightarrow \mathbb{R}$ 的非空实值函数空间， $S = (z_1, \dots, z_n)$ ，符号 σ_i 独立且等概率取 -1 与 1 。定义 $\mathcal{G}$ 在 S 上的 **经验 Rademacher 复杂度** (empirical Rademacher complexity) 为

$$\hat{\mathfrak{R}}_S(\mathcal{G}) = \mathbb{E}_\sigma \left[\sup_{f \in \mathcal{G}} \frac{1}{n} \sum_{i=1}^n \sigma_i f(z_i) \right]. \quad (5.14)$$

定义 5.11 期望 Rademacher 复杂度 设 $S \sim \mathcal{P}^n$ 。定义 $\mathcal{G}$ 的**期望 Rademacher 复杂度** (expected Rademacher complexity) 为

$$\mathfrak{R}_n(\mathcal{G}) = \mathbb{E}_{S \sim \mathcal{P}^n} \hat{\mathfrak{R}}_S(\mathcal{G}).$$

期望 Rademacher 复杂度是经验 Rademacher 复杂度对抽样结果的平均，依赖函数空间、样本量与抽样分布；经验版本只依赖已经固定的样本和函数空间。

定义中的期望位于上确界之外，意味着每次抽到新的符号都可以重新挑选函数。若 $\mathcal{G} = \{g_0\}$ 只含一个固定函数，随机符号的均值为零，经验复杂度也为零。若函数空间中的函数均取值于 $\{-1, 1\}$ ，并且能在互异样本点上实现任意正负号组合，它就能选到 $g(z_i) = \sigma_i$ ，经验复杂度为 1。两种情形的差别在于函数空间能否追随随机符号。同时，把所有函数值乘以正数也会按相同比例放大复杂度，因此数值尺度仍然重要。

图 5.2 把“追随随机符号”画成两次重抽样。输入 x_i 保持不变，改变的只是与真实标签无关的正负号；每抽到一组符号，都允许重新从同一个函数空间选函数。阈值只能把有序输入分成前后两段，允许任意标签的空间却能逐点匹配。

5.4.2 线性预测的复杂度

定义中的计算分为两步：对每组随机符号找到最大的加权平均值，再把这些最大值取平均。用一个一维线性模型可以具体看出这两步。取 $B > 0$ ，设 $f_w(x) = wx$ ， $|w| \leq B$ ，样本中的两个输入为 $x_1 = 1$ 、 $x_2 = 2$ 。固定符号后，需要最大化 $w(\sigma_1 + 2\sigma_2)/2$ 。若括号内为正，取 $w = B$ ；若为负，取 $w = -B$ 。四种符号组合 $(1, 1)$ 、 $(1, -1)$ 、 $(-1, 1)$ 、 $(-1, -1)$ 对应的最大值依次为 $3B/2$ 、 $B/2$ 、 $B/2$ 、 $3B/2$ ，所以这份样本上的经验 Rademacher 复杂度为 B 。这里每次选择的 w 可以不同，因为我们衡量的是整个函数空间适应随机符号的能力。

图 5.3 把这两步分开显示：每组符号对应一条关于 w 的得分直线，先在




图 5.2 固定六个输入上的两次随机符号抽样。圆点表示 $\sigma_i \in \{-1, 1\}$ ，其水平位置不变；中列曲线是取值为 $\{-1, 1\}$ 的递增阈值函数，右列可在这六个点上任意赋值。暖色圈标出符号与中列函数不一致的点。两组示意符号下，阈值空间的最大相关得分均为 $1/3$ ，任意标签空间均为 1 。两个实现只展示逐组选择，经验 Rademacher 复杂度还要对全部 2^6 组等概率符号取平均；随机符号不是被改写的任务标签。

允许的区间中选最高点，再平均四个最高得分。若事先固定同一个 w ，四种符号下的平均得分反而为零，所以定义中期望与上确界的顺序不能交换。




图 5.3 先最大化、再平均的经验 Rademacher 复杂度。固定教学输入 $x_1 = 1, x_2 = 2$ ，四幅小图分别对应等概率的四组随机符号；横轴为参数 w ，纵轴为得分 $q_{\sigma}(w)$ ，各图共用尺度。圆点标出每组符号下的最大值，所选参数允许随符号改变；四个最大值的平均为 B 。这些符号独立于数据的真实标签，图中直线由得分公式计算得到。

多维线性模型也能用同样的方法计算，并得到适用于任意样本量的上界。考虑线性得分 $f_{\mathbf{w}}(\mathbf{x}) = \mathbf{w}^{\top} \mathbf{x}$ 。若不限制参数大小，当 $\sum_i \sigma_i \mathbf{x}_i \neq 0$ 时，可以不断增大该方向上的参数，使 $\sum_i \sigma_i f_{\mathbf{w}}(\mathbf{x}_i)$ 任意大。因此，需要对允许的参数作出限制。设 $B > 0$ ，要求 $\|\mathbf{w}\|_2 \leq B$ ，即参数向量的长度不超过 B 。这里先计算预测得分的复杂度，再将结果用于损失函数；为此，令 $\mathcal{F} = \{\mathbf{x} \mapsto \mathbf{w}^{\top} \mathbf{x} : \|\mathbf{w}\|_2 \leq B\}$ ，并假定样本中的每个输入满足 $\|\mathbf{x}_i\|_2 \leq r$ 。记输入样本为 $S_X = (\mathbf{x}_1, \dots, \mathbf{x}_n)$ 。将线性得分代入定义，可得

$$\begin{aligned} \hat{\mathfrak{R}}_{S_X}(\mathcal{F}) &= \frac{1}{n} \mathbb{E}_{\sigma} \sup_{\|\mathbf{w}\|_2 \leq B} \mathbf{w}^{\top} \sum_i \sigma_i \mathbf{x}_i \\ &\leq \frac{B}{n} \sqrt{\sum_i \|\mathbf{x}_i\|_2^2} \leq \frac{Br}{\sqrt{n}}. \end{aligned} \quad (5.15)$$

这个界没有显式出现参数维数。固定随机符号后，令参数沿着 $\sum_i \sigma_i \mathbf{x}_i$ 的方向取长度 B ，最大内积就是该向量范数的 B 倍。期望范数不超过均方范数的平方根，而独立符号使不同样本间的交叉项平均为零，所以只剩

$\sum_i \|\mathbf{x}_i\|_2^2$ 。这里的维数无关保证依赖参数半径 B 与输入半径 r 均受控，不能在缺少这些条件时沿用。

5.4.3 由 Rademacher 复杂度估计期望风险

前面已经说明如何定义和计算复杂度，现在把它与期望风险联系起来。计算线性预测的复杂度时，函数值是预测得分；估计期望风险时，需要分析的函数值则是损失。设损失函数 ℓ 取值于 $[0, 1]$ ，对每个假设 h 定义 $g_h(z) = \ell(h(x), y)$ ，其中 $z = (x, y)$ ，并令 $\mathcal{G} = \{g_h : h \in \mathcal{H}\}$ 。于是 g_h 在样本上的平均值是 $\hat{R}_S(h)$ ，它在分布 $\mathcal{P}$ 下的期望是 $R_{\mathcal{P}}(h)$ 。控制这两个平均值之差，就能由经验风险得到期望风险上界。

定理 5.12 Rademacher 复杂度给出的期望风险上界 设 $\mathcal{G}$ 是抽样前确定的、取值于 $[0, 1]$ 的非空函数空间，并满足本章上述可测性约定。若 $S \sim \mathcal{P}^n$ ，则对任意 $\delta \in (0, 1)$ ，以至少 $1 - \delta$ 的概率，对所有 $g \in \mathcal{G}$ 同时有

$$\mathbb{E}_{z \sim \mathcal{P}} g(z) \leq \frac{1}{n} \sum_i g(z_i) + 2\mathfrak{R}_n(\mathcal{G}) + \sqrt{\frac{\log(1/\delta)}{2n}}. \quad (5.16)$$

另有一个由样本确定的上界：以至少 $1 - \delta$ 的概率，对所有 $g \in \mathcal{G}$ 同时有

$$\mathbb{E}_{z \sim \mathcal{P}} g(z) \leq \frac{1}{n} \sum_i g(z_i) + 2\hat{\mathfrak{R}}_S(\mathcal{G}) + 3\sqrt{\frac{\log(2/\delta)}{2n}}. \quad (5.17)$$

证明. 记 $\Phi(S) = \sup_{g \in \mathcal{G}} (\mathbb{E}g - \frac{1}{n} \sum_i g(z_i))$ 。它表示在这份样本上，经验均值对真实期望的最大低估程度。引入独立副样本 S' 后，先对副样本取平均再选择函数，不会大于先选择函数再取平均，因此

$$\mathbb{E}_S \Phi(S) \leq \mathbb{E}_{S, S'} \sup_{g \in \mathcal{G}} \frac{1}{n} \sum_i (g(z'_i) - g(z_i)).$$

对每对观测随机交换，可在差值前加入独立符号 σ_i 而不改变上述期望。将两份样本对应的和分别取上确界，并利用 σ_i 与 $-\sigma_i$ 同分布，得到

$$\mathbb{E}_S \Phi(S) \leq 2\mathfrak{R}_n(\mathcal{G}). \quad (5.18)$$

更换 S 中的一个观测， $\Phi(S)$ 最多改变 $1/n$ 。有界差分不等式于是保证，以至少 $1 - \delta$ 的概率， $\Phi(S)$ 不超过其期望加上 $\sqrt{\log(1/\delta)/(2n)}$ ，这就证明了第一个上界。经验 Rademacher 复杂度在更换一个观测时也最多改变 $1/n$ ，

因而以至少 $1 - \delta/2$ 的概率,

$$\mathfrak{R}_n(\mathcal{G}) \leq \hat{\mathfrak{R}}_S(\mathcal{G}) + \sqrt{\frac{\log(2/\delta)}{2n}}.$$

将第一个上界的失败概率也设为 $\delta/2$, 这两个不等式同时成立的概率至少为 $1 - \delta$. 代入即得第二个上界。■

令 $g = g_h$, 定理左侧就是假设 h 的期望风险, 右侧第一项就是它的经验风险。其余两项说明, 在多大程度上可以用经验风险代替期望风险。由于结论对所有假设同时成立, 即使 h 由算法观察样本后选出, 也能使用这个上界。第二个上界还允许根据当前样本计算或估计复杂度; 两个假设空间即使具有相同 VC 维, 也可能因在这批样本上的函数值不同, 而得到不同的期望风险上界。这类依赖数据的分析是 Rademacher 复杂度的重要用途³。

线性预测的得分不是零一损失。若某个损失函数对预测值满足 L -Lipschitz 条件, 即预测值改变 a 时损失至多改变 $L|a|$, **收缩引理** (contraction lemma) 可以把预测函数空间的复杂度界转给相应的损失函数空间。这个步骤需要核对损失的变化率, 不能直接把式 (5.15) 当成零一损失下的期望风险界。

这个结果可以具体用于分类。将标签写成 $y \in \{-1, 1\}$, 令 $f(\mathbf{x}) = \mathbf{w}^\top \mathbf{x}$ 。乘积 $yf(\mathbf{x})$ 称为带符号的分类间隔。这里的间隔位于得分尺度: 它为正当表示预测方向正确, 数值越大, 分类得分距离决策阈值 0 越远; 若要换成输入空间中的几何间隔, 还需除以参数向量的范数。给定 $\rho > 0$, 定义间隔损失

$$\ell_\rho(f(\mathbf{x}), y) = \begin{cases} 1, & yf(\mathbf{x}) \leq 0, \\ 1 - yf(\mathbf{x})/\rho, & 0 < yf(\mathbf{x}) < \rho, \\ 0, & yf(\mathbf{x}) \geq \rho. \end{cases}$$

预测错误时该损失为 1; 预测正确但间隔不足 ρ 时仍有一定惩罚。它取值于 $[0, 1]$ 、关于得分是 $1/\rho$ -Lipschitz 的, 并且不小于零一损失。若 $\|\mathbf{w}\|_2 \leq B$ 且 $\|\mathbf{x}\|_2 \leq r$ 几乎处处成立, 收缩引理和式 (5.15) 给出间隔损失空间的复杂度上界 $Br/(\rho\sqrt{n})$ 。于是, 以至少 $1 - \delta$ 的概率, 所有这些线性预测函数均满足

$$R_{\mathcal{P}}^{01}(\text{sign } f) \leq \frac{1}{n} \sum_i \ell_\rho(f(\mathbf{x}_i), y_i) + \frac{2Br}{\rho\sqrt{n}} + \sqrt{\frac{\log(1/\delta)}{2n}}. \quad (5.19)$$

这里 $R_{\mathcal{P}}^{01}$ 明确表示零一损失下的期望风险, 得分为 0 时采用固定分类规则。若样本上的间隔损失为零, 要使右侧不超过 ϵ , 所需样本量的充分上界为 $O(((Br/\rho)^2 + \log(1/\delta))/\epsilon^2)$ 。这个保证由范数与间隔的比值控制, 没有显

³ P. L. Bartlett, S. Mendelson, *Rademacher and Gaussian Complexities: Risk Bounds and Structural Results* In Journal of Machine Learning Research, 2002, vol. 3, pp. 463–482

式依赖输入维数；在高维且间隔较大的情形，它可能比仅依据半空间 VC 维得到的保证更有用。

这里增加了范数受限、输入有界和间隔损失较小的条件，因此并没有推翻二分类学习基本定理。单纯缩小参数范数而保持分类符号不变，通常也会缩小间隔，不能据此无条件改善上界。Rademacher 复杂度带来的改进，是能够利用这些具体条件，并把分析扩展到实值损失；它不保证对每个问题都给出比 VC 维更小的样本量，也不能使无限 VC 维的二分类假设空间在所有分布上变得 PAC 可学习。

要进一步得到 ERM 的可学习性保证，需要控制两个方向的偏差。将第一个上界分别用于 $\mathcal{G}$ 和 $1 - \mathcal{G} = \{1 - g : g \in \mathcal{G}\}$ 。两个函数类都取值于 $[0, 1]$ ；平移不改变期望均值与经验均值之差，而随机符号的对称性给出 $\mathfrak{R}_n(1 - \mathcal{G}) = \mathfrak{R}_n(\mathcal{G})$ 。分别分配失败概率 $\delta/2$ ，可知以至少 $1 - \delta$ 的概率，所有假设均满足

$$|R_{\mathcal{P}}(h) - \hat{R}_S(h)| \leq 2\mathfrak{R}_n(\mathcal{G}) + \sqrt{\frac{\log(2/\delta)}{2n}}.$$

若 $\hat{h}$ 是 ERM 输出，按照前文比较两次经验风险与期望风险的方法，就得到

$$R_{\mathcal{P}}(\hat{h}) - \inf_{h \in \mathcal{H}} R_{\mathcal{P}}(h) \leq 4\mathfrak{R}_n(\mathcal{G}) + 2\sqrt{\frac{\log(2/\delta)}{2n}}. \quad (5.20)$$

因此，若对某个分布有 $\mathfrak{R}_n(\mathcal{G}) \rightarrow 0$ ，ERM 的期望风险就以高概率接近假设空间所能达到的最小期望风险。若进一步存在对所有允许分布都成立的上界 $\mathfrak{R}_n(\mathcal{G}) \leq a_n$ ，且 $a_n \rightarrow 0$ ，便能选出不依赖具体分布的样本量，得到不可知 PAC 保证。仅在某个分布下复杂度很小，并不足以推出分布无关 PAC 可学习。

5.4.4 高斯复杂度

前面的分析用随机符号衡量函数空间拟合随机波动的能力。具体来说，固定样本后，给每个函数值 $g(z_i)$ 乘上一个独立的 $\sigma_i \in \{-1, 1\}$ ，再从函数空间中选择使加权和最大的函数。这里每个系数的绝对值都是 1，随机变化的只有正负号。

同样的分析思路也可以使用独立标准高斯变量 ξ_i 作为系数。此时，系数既有正负之分，绝对值也会变化：某次抽样可能更强调第一个样本点，另一次则更强调其他样本点。对每组系数选择使加权和最大的函数，再对系数取平均，就得到**经验高斯复杂度**（empirical Gaussian complexity）。这些系数只用于度量函数空间，既不替代真实标签，也不改变数据的抽样分布。

引入高斯复杂度的意义在于提供另一种估计期望风险上界的途径。若一

个函数空间的高斯复杂度更容易求出上界，就可以通过它与 Rademacher 复杂度的比较，沿用前面的泛化定理。下面先给出定义，再说明这一比较关系及其适用方向。

定义 5.13 经验高斯复杂度 设 $\mathcal{G}$ 为 $Z \rightarrow \mathbb{R}$ 的非空实值函数空间， $S = (z_1, \dots, z_n)$ 。令 ξ_i 相互独立且服从 $\mathcal{N}(0, 1)$ ，定义 $\mathcal{G}$ 在 S 上的经验高斯复杂度为

$$\hat{\mathfrak{G}}_S(\mathcal{G}) = \mathbb{E}_\xi \left[\sup_{g \in \mathcal{G}} \frac{1}{n} \sum_i \xi_i g(z_i) \right].$$

高斯系数的幅度可变，Rademacher 符号的幅度恒为 1，因此一般不能断言两种复杂度只差普通常数。写成 $\xi_i = \sigma_i |\xi_i|$ 并利用上确界的凸性可得 $\hat{\mathfrak{G}}_S(\mathcal{G}) \geq \sqrt{2/\pi} \hat{\mathfrak{R}}_S(\mathcal{G})$ 。因此，若已得到 $\hat{\mathfrak{G}}_S(\mathcal{G}) \leq b(S)$ ，便有 $\hat{\mathfrak{R}}_S(\mathcal{G}) \leq \sqrt{\pi/2} b(S)$ ，可代入式 (5.17) 来控制期望风险。

这给出了直接使用高斯复杂度的期望风险上界。

定理 5.14 高斯复杂度给出的期望风险上界 设 $\mathcal{G} = \{g_h : h \in \mathcal{H}\}$ 为抽样前确定的、取值于 $[0, 1]$ 的损失函数空间，并满足定理 5.12 的可测性条件。若 $S \sim \mathcal{P}^n$ ，则对任意 $\delta \in (0, 1)$ ，以至少 $1 - \delta$ 的概率，所有 $h \in \mathcal{H}$ 同时满足

$$R_{\mathcal{P}}(h) \leq \hat{R}_S(h) + \sqrt{2\pi} \hat{\mathfrak{G}}_S(\mathcal{G}) + 3\sqrt{\frac{\log(2/\delta)}{2n}}. \quad (5.21)$$

证明. 在式 (5.17) 中取 $g = g_h$ ，并代入 $2\hat{\mathfrak{R}}_S(\mathcal{G}) \leq \sqrt{2\pi} \hat{\mathfrak{G}}_S(\mathcal{G})$ ，即得结论。■

实际使用时，先计算所选假设的经验风险，再为损失函数空间的经验高斯复杂度求一个上界，将两者代入式 (5.21) 即可。若已有复杂度上界 $b(S)$ ，也可以直接用 $b(S)$ 替换其中的经验高斯复杂度。这个结论对所有假设同时成立，因此同样适用于观察样本后选出的假设。

高斯复杂度在这里提供了估计复杂度项的另一种办法，并不保证得到更小的期望风险上界。反方向可能付出随 n 增长的因子。例如限制向量仅为 $\{\pm \mathbf{e}_i : 1 \leq i \leq n\}$ 时，Rademacher 复杂度为 $1/n$ ，高斯复杂度为 $\mathbb{E} \max_i |\xi_i|/n$ 。两种工具联系紧密，但互换两类复杂度得到的期望风险界时仍须检查具体比较条件。

5.5 样本压缩

前两节分别用 VC 维和 Rademacher 复杂度分析假设空间，进而控制经验风险与期望风险的关系。还有一种办法从学习算法的输出入手：如果只

保留少量带标签观测，就能重新构造出一个与全部样本一致的假设，那么这些被保留的观测能否为它的期望风险提供保证？**样本压缩**（sample compression）研究的正是这种从少量观测重构假设的方式。它既可以用于估计重构假设的期望风险，也可以在压缩规模受到统一控制时证明可学习性。

5.5.1 从样本到假设的重构

考虑递增阈值 $h_t(x) = \mathbb{I}\{x \geq t\}$ 。四个输入 0.1、0.3、0.7、0.9 的标签依次为 0、0、1、1。只保留最小的正例 (0.7, 1)，并约定将保留输入作为阈值，就能重构 $h_{0.7}$ 。虽然其余三个观测已经被丢弃，这个假设仍然将四个输入全部分对。这里重构的是一个与样本一致的假设，并不要求恢复生成数据的真实阈值。

这一办法适用于每份可由递增阈值正确分类的有限样本。只要样本中有正例，就保留最小的正例；所有负例都位于它的左侧，其他正例都位于它的右侧或与之重合，因而重构阈值与全部样本一致。若样本没有正例，则不保留任何观测，并约定由空样本重构处处预测 0 的假设。这个假设可能不属于实数阈值空间，因此本节允许重构假设不属于原假设空间。

一般的压缩方案包含两个预先确定的步骤。压缩映射读取完整样本，选择少量带标签观测；重构映射只能读取这些被保留的观测，并据此输出假设。有时还需要保留一个有限长度的二进制串，以说明采用哪一种重构方式。这部分称为**旁信息**（side information），它也必须计入压缩规模，不能借此保存任意多的原样本信息。

定义 5.15 一致样本压缩方案 设 $\mathcal{H} \subseteq \{0, 1\}^X$ ， k, b 为非负整数。一个 (k, b) 一致样本压缩方案由固定的确定性映射 κ 和 ρ 组成。对任意有限样本 $S = ((x_i, y_i))_{i=1}^n$ ，若存在 $h \in \mathcal{H}$ 使 $h(x_i) = y_i$ 对所有 i 成立，则 $\kappa(S) = (S_I, u)$ 满足

$$I \subseteq \{1, \dots, n\}, \quad |I| \leq k, \quad u \in \{0, 1\}^b,$$

其中 S_I 按原样本中的次序排列。重构映射仅以 (S_I, u) 为输入，输出 $\rho(S_I, u) : X \rightarrow \{0, 1\}$ ，且满足

$$\rho(S_I, u)(x_i) = y_i, \quad i = 1, \dots, n.$$

这个定义要求同一对映射对每份可实现样本都有效，且 k, b 不随样本量增长。重构映射不能读取未保留的观测，也不能获得未计入旁信息的原始位置编号。前面的阈值方案满足 $k = 1, b = 0$ ；保留一个正例还是空样本，已经足以区分两种重构方式。

5.5.2 期望风险与可学习性保证

仅仅重构出一个与样本一致的假设，还不能直接说明其期望风险小。压缩规模的作用在于限制算法能以多少种方式构造这个假设。对一份大小为 n 的样本，保留 j 个观测有 $\binom{n}{j}$ 种位置选择，旁信息有 2^b 种。因此，总共只需考虑 $2^b \sum_{j=0}^k \binom{n}{j}$ 种重构方式。

对于其中一种预先固定的选择，重构假设只依赖被保留的观测，其余观测仍然可以检验它的预测是否正确。如果它的期望风险很大，却把这些独立观测全部分对，这种情形的概率就很小。压缩算法虽然是在看过完整样本后才作出选择，但可以把每种选择对应的失败概率相加，从而控制最终输出的期望风险。

定理 5.16 一致样本压缩的期望风险上界 设 $\mathcal{H}$ 具有一个 (k, b) 一致样本压缩方案，且压缩、重构及输出损失满足第 4.1 节的可测性与可分性约定。若 $S \sim \mathcal{P}^n$ 、 $n > k$ ，且 $\mathcal{P}$ 对 $\mathcal{H}$ 可实现，则对任意 $\delta \in (0, 1)$ ，以至少 $1 - \delta$ 的概率，重构假设 $h_S = \rho(\kappa(S))$ 的零一损失期望风险满足

$$R_{\mathcal{P}}(h_S) \leq \frac{b \log 2 + \log \left(\sum_{j=0}^k \binom{n}{j} \right) + \log(1/\delta)}{n - k}. \quad (5.22)$$

证明. 固定位置集 $I \subseteq \{1, \dots, n\}$ 、 $|I| = j \leq k$ 及旁信息 u 。这里只固定一种可能的重构方式，不附加“压缩算法恰好选中了它”的条件。给定 S_I 后，假设 $h_{I,u} = \rho(S_I, u)$ 便已确定，其余 $n - j$ 个观测仍然相互独立且服从 $\mathcal{P}$ 。若 $R_{\mathcal{P}}(h_{I,u}) > \varepsilon$ ，它把这些观测全部分对的条件概率至多为

$$(1 - \varepsilon)^{n-j} \leq e^{-(n-j)\varepsilon} \leq e^{-(n-k)\varepsilon}.$$

再对 S_I 取平均，便知对这一固定的 (I, u) ，同时出现期望风险超过 ε 和与全部样本一致的概率至多为 $e^{-(n-k)\varepsilon}$ 。

压缩方案最终输出的假设必然对应某个 (I, u) ，并且与全部样本一致。因此，若最终输出的期望风险超过 ε ，上述失败情形至少在一种选择中发生。把所有选择对应的概率相加，得到

$$\mathbb{P}\{R_{\mathcal{P}}(h_S) > \varepsilon\} \leq 2^b \left(\sum_{j=0}^k \binom{n}{j} \right) e^{-(n-k)\varepsilon}.$$

令右侧不超过 δ ，对数变换后即得式 (5.22)。若该式右侧大于或等于 1，结论由零一损失期望风险不超过 1 直接成立。 ■

分子中的两项分别记录保留位置和旁信息的选择数，分母中的 $n - k$ 则

是至少还有多少个未保留观测可以检验重构假设。这里的 $\log$ 为自然对数，所以 b 比特对应 $b \log 2$ 。对阈值方案， $k = 1, b = 0$ ，且 $\sum_{j=0}^1 \binom{n}{j} = n + 1$ ，于是

$$R_{\mathcal{P}}(h_S) \leq \frac{\log(n+1) + \log(1/\delta)}{n-1}.$$

例如 $n = 100$ 、 $\delta = 0.05$ 时，这个上界约为 0.077：以至少 95% 的概率，重构阈值的期望错误率不超过 7.7%。这是通用压缩分析给出的充分保证，不意味着阈值学习的最优样本量必须包含 $\log n$ 因子。

定理 5.17 有界样本压缩推出 PAC 可学习 在上述可测性条件下，若 $\mathcal{H}$ 存在固定有限的 (k, b) 一致样本压缩方案，则学习算法 $A(S) = \rho(\kappa(S))$ 使 $\mathcal{H}$ 可实现 PAC 可学习。具体地，只要 $n > k$ 且

$$b \log 2 + \log \left(\sum_{j=0}^k \binom{n}{j} \right) + \log(1/\delta) \leq (n-k)\varepsilon,$$

就有 $\mathbb{P}\{R_{\mathcal{P}}(A(S)) \leq \varepsilon\} \geq 1 - \delta$ ，且这一样本量条件不依赖具体的可实现分布 $\mathcal{P}$ 。

证明. 当 $k = 0$ 时，组合数之和为 1；当 $k \geq 1$ 固定时， $\sum_{j=0}^k \binom{n}{j} \leq (k+1)n^k$ 。因此，前一定理的分子至多按 $\log n$ 的量级增长，分母则按 n 增长。对任意 $\varepsilon, \delta \in (0, 1)$ ，都存在一个有限样本量阈值，使此后所有 n 都满足所列条件。前一定理随即给出 PAC 要求的期望风险保证。 ■

这两个定理承担不同作用：前者估计某次学习输出的期望风险，后者说明同一个算法可以在所有可实现分布上达到任意给定精度。它们直接依赖于样本一致的条件；存在标签噪声时，重构假设未必能分对全部样本，不能直接套用这个证明。它们也只给出统计保证，压缩与重构是否容易计算仍需单独分析。

5.5.3 与 VC 维及 Rademacher 复杂度的关系

VC 维和样本压缩从两个方向描述假设空间。VC 维考察一组输入能实现多少种不同预测，样本压缩考察与样本一致的假设能够由多少个观测重构。在二分类设定中，有界的一致压缩方案推出可实现 PAC 可学习，再由二分类学习基本定理推出 VC 维有限。也可以直接通过计数看到这层限制。

定理 5.18 压缩规模对打散的限制 若 $\mathcal{H}$ 具有 (k, b) 一致样本压缩

方案，并能打散 m 个不同输入，则

$$2^m \leq 2^b \sum_{j=0}^{\min\{k,m\}} \binom{m}{j} 2^j.$$

特别地，固定有限的 k, b 意味着 $\text{VC}(\mathcal{H}) < \infty$ 。

证明. 将这 m 个输入按固定次序排列。由于它们能被打散，全部 2^m 种 0/1 预测都对应一份可实现的带标签样本。保留 j 个输入有 $\binom{m}{j}$ 种选择，它们的标签有 2^j 种，再加上 2^b 种旁信息，得到右侧的描述数。两个不同的完整预测不能被压缩成同一份描述，否则固定的重构映射就必须对同一输入同时给出两个不同标签。因此描述数至少为 2^m 。对固定 k, b ，右侧随 m 至多按多项式增长，左侧按指数增长，不等式不可能对任意大的 m 成立。■

反过来，有限 VC 维也保证存在规模不依赖样本量的压缩方案。Moran 与 Yehudayoff 证明，VC 维为 d 的二分类假设空间存在规模为 $2^{O(d)}$ 的样本压缩方案⁴。因此，在通常的可测性条件下，有限 VC 维、二分类 PAC 可学习性和存在有界规模的压缩方案相互联系。不过，存在性并未说明能压缩到多小。**样本压缩猜想** (sample compression conjecture) 进一步要求与 d 成线性量级的压缩规模；Attias 等人在 2025 年的研究中仍将这一一般性问题列为未解决问题⁵。比较不同压缩规模时，需要同时核对保留观测数和旁信息量，不能把大量描述信息藏在旁信息中。

Rademacher 复杂度与样本压缩则采用了不同的证明对象。Rademacher 复杂度控制整个损失函数空间在样本上的随机波动，所得期望风险上界对空间中的所有假设同时成立；压缩分析只要求控制由指定重构映射和有限描述产生的假设，不必证明整个假设空间都满足同样精度的一致收敛。前者衡量函数值适应随机符号的能力，后者计数可能的样本描述，所以压缩规模不能直接作为 Rademacher 复杂度代入公式。

两种方法都需要防止算法利用样本中的偶然性：Rademacher 分析对整个函数空间控制这种选择的影响，压缩分析则限制重构假设所依赖的信息。上一节的有界损失上界允许非零经验风险；本节的一致压缩上界利用了经验风险为零，通常给出固定 k, b 下约为 $\log n/n$ 的衰减量级。两者的条件不同，不能仅凭这个量级比较优劣。即使某次样本碰巧容易压缩，也不自动说明整个假设空间可学习；PAC 结论需要一个对所有可实现样本有效、规模统一受控的方案。

5.6 集成学习

前面讨论了如何评估一个假设的期望风险。本节进一步考虑，能否把多个假设组合起来，得到比单个假设更可靠的预测。**集成学习** (ensemble

⁴S. Moran, A. Yehudayoff, *Sample Compression Schemes for VC Classes* In Journal of the ACM, 2016, vol. 63, no. 3, pp. 21:1–21:10

⁵I. Attias, S. Hanneke, A. Ramaswami, *Sample Compression Scheme Reductions* In Proceedings of the 36th International Conference on Algorithmic Learning Theory, 2025, pp. 134–162

learning) 将多个基假设的输出通过投票或平均形成最终预测。组合既可能降低单次训练的随机波动, 也可能表达单个基假设无法表达的分类边界; 但增加假设数本身并不保证期望风险下降。

本节围绕两个问题展开: 投票在什么条件下能够改善预测, 以及如何主动构造满足要求的基假设。前者需要分析错误之间的关系, 后者由提升方法给出一种具体实现。最终还要控制投票假设的期望风险, 才能把样本上的改善转化为可学习性结论。

5.6.1 投票、平均与错误相关性

本节将标签写成 $\{-1, 1\}$, 并约定得分为 0 时预测 1。给定基假设 $h_1, \dots, h_T : X \rightarrow \{-1, 1\}$, 以及非负权重 a_t 、 $\sum_t a_t = 1$, 定义

$$f(x) = \sum_{t=1}^T a_t h_t(x), \quad H(x) = \text{sign}(f(x)).$$

$f(x)$ 是加权投票得分, $H(x)$ 是最终分类假设。取 $a_t = 1/T$ 便得到多数投票。若允许从基假设空间 $\mathcal{B}$ 选取任意有限个假设, 则这些得分函数构成 $\mathcal{B}$ 的**凸包** (convex hull), 记为 $\text{conv}(\mathcal{B})$ 。这里凸包中的元素是实值得分函数, 不能与阈值化之后的二分类假设混为一谈。

三个假设在某个输入上的预测为 $(1, 1, -1)$ 时, 多数投票输出 1。若真实标签是 1, 这次投票纠正了第三个假设的错误; 若三个假设都预测为 -1 , 则投票无法纠正它们共同的错误。因此, 需要关注基假设是否在同一批输入上犯错。下面的独立性条件给出一个理想化的充分保证。

定理 5.19 独立错误下的多数投票 设 T 为奇数。对 $\mathcal{P}$ 几乎处处的 (x, y) , 假设由训练随机性产生的错误指标 $E_t = \mathbb{I}\{h_t(x) \neq y\}$ 在给定 (x, y) 后相互独立, 且 $\mathbb{E}[E_t | x, y] \leq 1/2 - \gamma$, 其中 $\gamma > 0$ 。则等权多数投票满足

$$\mathbb{E}_{\text{train}} R_{\mathcal{P}}(H) \leq e^{-2T\gamma^2}.$$

证明. 给定 (x, y) , 投票出错意味着 $T^{-1} \sum_t E_t \geq 1/2$ 。这一平均值的条件期望至多为 $1/2 - \gamma$, 由独立有界变量的 Hoeffding 不等式, 出错概率至多为 $e^{-2T\gamma^2}$ 。再对 $(x, y) \sim \mathcal{P}$ 取期望即得结论。■

这里要求每个输入处的条件错误率受控, 而且错误条件独立; 仅仅知道每个基假设的总体期望风险小于 $1/2$ 并不足够。反复训练同一个算法时, 难分类的输入可能让所有假设一起出错。这个定理解释了互不相关的错误为何有利于投票, 但不能直接用作一般集成算法的期望风险保证。

装袋法 (bootstrap aggregating, bagging) 通过对原样本有放回地重采样,

训练多个基假设，再平均得分或投票。它主要尝试减小训练样本扰动带来的预测变化。例如，在固定输入 x 处，若实值得分 $F_1(x), \dots, F_T(x)$ 各有方差 v ，两两协方差均为 c ，则展开平均值的方差可得

$$\text{Var}\left(\frac{1}{T} \sum_t F_t(x)\right) = \frac{v}{T} + \frac{T-1}{T}c.$$

当 $c = 0$ 时，平均得分的方差为 v/T ；当 $c = v$ 时，平均并不降低方差。这里的随机性来自训练过程和数据，重采样共享同一份原样本，不能据此假定这些得分无条件独立。方差降低也不自动等于零一损失期望风险降低，因为分类还取决于得分是否越过 0。随机森林在重采样之外随机选择分裂特征，也是在构造有差异的基假设；其具体算法留待模型章节讨论⁶。

⁶S. Shalev-Shwartz, S. Ben-David, *Understanding Machine Learning: From Theory to Algorithms*, Cambridge University Press, 2014, 1st ed.

5.6.2 弱学习与提升

第 4 章把弱学习描述为获得一个固定优势：在每个可实现分布上，统一算法都能以高概率输出期望风险不超过 $1/2 - \gamma$ 的分类器，其中 $\gamma \in (0, 1/2)$ 与分布无关。一次这样的学习只保证优于随机猜测，尚未达到任意小的误差容限。**提升** (boosting) 反复调用弱学习器，并改变每一轮关注的样本，使多个弱分类器的错误相互补偿。

弱学习要求同一个学习器对每个允许的可实现分布都获得优势，而不只是对原始分布有效。提升算法会改变各个样本的权重，这相当于不断提出新的分类分布；若弱学习器只能在最初的分布上优于随机猜测，就不足以支持后续保证。这里的弱优势可以很小，但必须在这些分布上统一成立。

5.6.3 经验风险

AdaBoost 是提升方法的一个具体构造。它给训练样本赋予非负权重；某轮分错的样本在下一轮获得更大权重。每轮学到的假设还会参与最终加权投票。经验风险的下降可以直接由权重更新证明，但要得到 PAC 保证，还需单独控制最终投票的期望风险。

沿用本节的 $-1, 1$ 标签和基假设输出约定， $y_i h_t(x_i) = 1$ 表示分对， $y_i h_t(x_i) = -1$ 表示分错。令初始样本权重 $D^{(1)}(i) = 1/n$ ，其中 $D^{(t)}(i)$ 是第 t 轮分配给样本 i 的权重，且 $\sum_i D^{(t)}(i) = 1$ 。弱学习器返回假设 h_t 后，算法计算其加权错误率 $e^{(t)} = \sum_i D^{(t)}(i) \mathbb{I}\{h_t(x_i) \neq y_i\}$ 。在 $0 < e^{(t)} < 1/2$ 时，令

$$\alpha^{(t)} = \frac{1}{2} \log \frac{1 - e^{(t)}}{e^{(t)}}, \quad D^{(t+1)}(i) = \frac{D^{(t)}(i) e^{-\alpha^{(t)} y_i h_t(x_i)}}{Z^{(t)}}, \quad (5.23)$$

其中 $Z^{(t)} = \sum_i D^{(t)}(i) e^{-\alpha^{(t)} y_i h_t(x_i)}$ 使新权重和为 1。若 $e^{(t)} = 0$ ，当前假设已与全部样本一致，可直接输出该假设并停止；若 $e^{(t)} \geq 1/2$ ，本轮不满足所需优势。在预先固定平局规则后，最终输出 $H_T(x) = \text{sign}(\sum_t \alpha^{(t)} h_t(x))$ 。

重加权改变的是下一轮计算错误率时每个样本的分量。若一个样本被当前弱分类器分错, 指数因子为 $e^{\alpha^{(t)}}$, 其相对权重上升; 分对时因子为 $e^{-\alpha^{(t)}}$, 相对权重下降。下一轮弱学习器若仍想取得小于 $1/2$ 的加权错误, 就必须更多照顾此前失败的样本。 $e^{(t)}$ 越小, $\alpha^{(t)}$ 越大, 最终投票中该轮假设的权重也越大。

一次数值更新可以说明公式的作用。设四个样本的初始权重都是 $1/4$, 本轮只分错第一个, 则 $e^{(t)} = 1/4$, $\alpha^{(t)} = \frac{1}{2} \log 3$ 。归一化后, 第一个样本的权重变为 $1/2$, 另外三个各为 $1/6$ 。下一轮若继续把第一个样本分错, 仅这一次错误就占权重的一半, 弱学习器必须改变判断才能保持严格优于 $1/2$ 的加权错误率。

定理 5.20 AdaBoost 经验风险界 若每轮的加权错误率满足 $0 < e^{(t)} < 1/2$, 并记 $\gamma^{(t)} = 1/2 - e^{(t)}$, 则

$$\hat{R}_S(H_T) \leq \prod_{t=1}^T Z^{(t)} = \prod_{t=1}^T 2\sqrt{e^{(t)}(1-e^{(t)})} \leq \exp\left(-2 \sum_{t=1}^T (\gamma^{(t)})^2\right). \quad (5.24)$$

证明. 递推式展开后有 $D^{(T+1)}(i) = n^{-1} \exp(-y_i \sum_t \alpha^{(t)} h_t(x_i)) / \prod_t Z^{(t)}$ 。若 H_T 在样本 i 上出错, 则 $y_i \sum_t \alpha^{(t)} h_t(x_i) \leq 0$, 指数项至少为 1。将上式对所有训练样本求和, 并利用 $\sum_i D^{(T+1)}(i) = 1$, 得到误分类比例不超过 $\prod_t Z^{(t)}$ 。按正确与错误两组求和可得 $Z^{(t)} = 2\sqrt{e^{(t)}(1-e^{(t)})}$, 最后用 $\sqrt{1-4(\gamma^{(t)})^2} \leq e^{-2(\gamma^{(t)})^2}$ 。 ■

5.6.4 可学习性

若每轮都有 $e^{(t)} \leq 1/2 - \gamma$, 取 $T \geq \log(2/\epsilon)/(2\gamma^2)$, 定理 5.20 便使经验风险不超过 $\epsilon/2$ 。要进一步保证期望风险小, 还要控制算法根据样本选择基假设和投票权重所带来的偏差。这里并不需要基假设空间有限; 关键在于它在有限输入上能够给出多少种不同预测。

例如, 实数阈值有无限多个, 但在 m 个有序输入上只能给出 $m+1$ 种不同预测。选择 T 个阈值时, 即使每个阈值的数值都有无限种可能, 在这批输入上产生的 T 列预测结果也至多有 $(m+1)^T$ 种。一般的无限基假设空间可以用生长函数作同样的计数。

设 $\mathcal{B} \subseteq \{-1, 1\}^X$ 是抽样前固定的基假设空间, $\mathcal{V}_T$ 表示由 T 个基假设和任意实数权重形成的投票分类假设空间, 平局规则固定。将 $-1, 1$ 重新编码为 $0, 1$ 不改变预测数目, 因此仍沿用前文的生长函数及 VC 维记号。以下讨论沿用第 4.1 节的可测性与可分性约定。

定理 5.21 投票假设空间的生长函数 对任意 $T \geq 1$ 及 $m \geq T + 1$, 有

$$\Pi_{\mathcal{V}_T}(m) \leq \Pi_{\mathcal{B}}(m)^T \left(\frac{em}{T+1} \right)^{T+1}. \quad (5.25)$$

若 $d = \text{VC}(\mathcal{B})$ 满足 $1 \leq d < \infty$, 则在 $m \geq \max\{d, T+1\}$ 时,

$$\log \Pi_{\mathcal{V}_T}(m) \leq dT \log \frac{em}{d} + (T+1) \log \frac{em}{T+1}. \quad (5.26)$$

特别地, 对每个固定有限的 T , $\mathcal{V}_T$ 的 VC 维有限。

证明. 固定 m 个输入。每个基假设在这些输入上有至多 $\Pi_{\mathcal{B}}(m)$ 种不同预测, 所以 T 个基假设形成的预测矩阵至多有 $\Pi_{\mathcal{B}}(m)^T$ 种。固定其中一个矩阵后, 每个输入对应一个 T 维向量 $(h_1(x), \dots, h_T(x))$; 改变投票权重, 就是在这些向量上改变一个线性分类器。这个分类器属于 T 维仿射半空间假设空间, 其 VC 维为 $T+1$ 。Sauer-Shelah 引理因此将每个固定矩阵上的投票预测数目限制为 $(em/(T+1))^{T+1}$ 。对所有矩阵计数, 得到第一式。

当基假设空间的 VC 维为 d 时, 再代入 $\Pi_{\mathcal{B}}(m) \leq (em/d)^d$, 便得到第二式。固定 d, T 后, 这个上界对 $\Pi_{\mathcal{V}_T}(m)$ 只允许多项式增长, 因此不可能对任意大的 m 都达到打散所需的 2^m , 故投票空间的 VC 维有限。若 $d = 0$, 非空 $\mathcal{B}$ 在每个输入上的预测唯一, 第一式同样给出有限 VC 维。 ■

这个证明将无限空间的计数转化为有限输入上的预测计数。若 $\mathcal{B}$ 本来就有限, 还可使用 $\Pi_{\mathcal{B}}(m) \leq |\mathcal{B}|$, 得到熟悉的 $T \log |\mathcal{B}|$ 项。因此, 有限基假设空间只是上述分析的一种特殊情形。对无限但 VC 维有限的基假设空间, 每个固定轮数的投票空间同样满足一致收敛。

定理 5.22 有限 VC 维基假设空间下的弱学习提升 设 $\mathcal{H}$ 为目标假设空间, $\mathcal{B}$ 为固定的非空基假设空间, $\text{VC}(\mathcal{B}) < \infty$, 允许 $|\mathcal{B}| = \infty$ 。假设存在弱学习器, 对每个 $\mathcal{H}$ 可实现分布和每个 $\eta \in (0, 1)$, 使用统一有限数量的独立样本后, 以至少 $1 - \eta$ 的概率输出 $h \in \mathcal{B}$, 其零一损失期望风险不超过 $1/2 - \gamma$, 其中 $\gamma > 0$ 与分布无关。则允许从原样本的加权经验分布重新抽样的 AdaBoost 构造, 能够非恰当地可实现 PAC 学习 $\mathcal{H}$ 。

证明. 给定 ε, δ , 在抽取原样本前固定 $T = \lceil \log(2/\varepsilon)/(2\gamma^2) \rceil$ 。由定理 5.21, $\mathcal{V}_T$ 的 VC 维有限, 故可以选择与具体分布无关的原始样本量 n , 使其以至少 $1 - \delta/2$ 的概率满足

$$\sup_{H \in \mathcal{V}_T} |R_{\mathcal{P}}(H) - \hat{R}_S(H)| \leq \varepsilon/2.$$

原始分布对 $\mathcal{H}$ 可实现, 所以原样本几乎必然与某个目标假设一致。每轮改变观测权重并不改变标签, 因此加权经验分布也对 $\mathcal{H}$ 可实现。条件于原样本和此前各轮结果, 从当前加权经验分布独立重采样, 再以失败概率 $\delta/(2T)$ 调用弱学习器, 即能以相应概率获得加权错误率不超过 $1/2 - \gamma$ 的基假设。把各轮失败概率相加, 所有轮次都获得优势的的概率至少为 $1 - \delta/2$ 。

在两类成功事件同时发生时, AdaBoost 的经验风险不超过 $\varepsilon/2$, 而其输出属于 $\mathcal{V}_T$, 所以期望风险不超过 ε 。若提前找到经验风险为零的基假设, 则直接输出它; 其余投票权重取零即可将其视为 $\mathcal{V}_T$ 中的元素。总失败概率至多为 δ , 其中包含原样本抽样和各轮学习的随机性, 故得到 PAC 保证。 ■

因此, 无限基假设空间并不妨碍提升; 有限 VC 维和对所有可实现分布统一成立的弱优势, 足以支撑这里的构造。但有限 VC 维本身并不保证基假设能够弱学习任意给定的目标空间 $\mathcal{H}$, 弱学习条件仍须另外满足。这一定理也没有假定各轮错误相互独立⁷。

上述证明对给定精度先固定 T , 再选择足够的样本量。若基假设空间的 VC 维无限, 或者在固定样本量下任意增加轮数, 便不能直接依靠这个有限 VC 维结论获得统一保证。即使每轮经验风险继续改善, 也还需要其他复杂度条件来控制期望风险。存在标签噪声时, 每个重加权分布上的弱优势也可能不再成立, 因此这里的可实现证明不能直接扩展为不可知提升保证。

⁷ S. Shalev-Shwartz, S. Ben-David, *Understanding Machine Learning: From Theory to Algorithms*, Cambridge University Press, 2014, 1st ed.

5.6.5 估计期望风险

按投票轮数计数可以证明可学习性, 但可能高估一个实际集成模型的复杂度。另一种分析利用上一节的 Rademacher 复杂度, 研究归一化投票得分 $f = \sum_t a_t h_t$ 。在样本 (x, y) 上, $yf(x)$ 表示正确一侧的总权重减去错误一侧的总权重。例如, 正确一侧占 0.9 时, 间隔为 0.8; 只占 0.51 时, 间隔为 0.02。两者都分类正确, 但后一种投票更接近改变类别的边界。

定理 5.23 凸组合的 Rademacher 复杂度 对任意固定输入样本 S_X 和非空有界实值函数空间 $\mathcal{B}$, 有

$$\hat{\mathfrak{R}}_{S_X}(\text{conv}(\mathcal{B})) = \hat{\mathfrak{R}}_{S_X}(\mathcal{B}).$$

证明. 固定随机符号后, 加权和是函数值的线性函数。对任意凸组合,

$$\frac{1}{n} \sum_i \sigma_i \sum_t a_t h_t(x_i) = \sum_t a_t \left(\frac{1}{n} \sum_i \sigma_i h_t(x_i) \right) \leq \sup_{h \in \mathcal{B}} \frac{1}{n} \sum_i \sigma_i h(x_i).$$

而每个基假设本身也属于凸包，两边的上确界相等。对随机符号取期望即得结论。 ■

取上一节定义的间隔损失 ℓ_ρ ，其中 $\rho > 0$ 在抽样前固定。它不小于零一损失，而且关于得分的 Lipschitz 常数为 $1/\rho$ 。对损失空间应用收缩引理及经验 Rademacher 期望风险上界，便得到：以至少 $1 - \delta$ 的概率，所有 $f \in \text{conv}(\mathcal{B})$ 同时满足

$$R_\rho^{01}(\text{sign } f) \leq \frac{1}{n} \sum_i \ell_\rho(f(x_i), y_i) + \frac{2}{\rho} \hat{\mathfrak{R}}_{S_X}(\mathcal{B}) + 3\sqrt{\frac{\log(2/\delta)}{2n}}. \quad (5.27)$$

对固定标签乘上 y_i 不会改变随机符号的分布，所以这里使用输入样本上的基假设复杂度。这一推导也说明，凸包复杂度的等式控制的是实值得分，并非直接控制阈值化后的零一损失。

这个上界同样适用于无限基假设空间，因为凸包复杂度的证明并未使用基假设总数。例如，若 $\mathcal{B} \subseteq \{-1, 1\}^X$ 的 VC 维为 d ，则在 $1 \leq d \leq n$ 时，对固定样本上的有限预测向量应用有限类 Rademacher 上界，再用 Sauer-Shelah 引理，可得

$$\hat{\mathfrak{R}}_{S_X}(\mathcal{B}) \leq \sqrt{\frac{2 \log \Pi_{\mathcal{B}}(n)}{n}} \leq \sqrt{\frac{2d \log(en/d)}{n}}.$$

这里每个预测向量的欧氏范数为 $\sqrt{n}$ ，所以即使基假设有无限多个，复杂度仍由有限样本上的预测数目控制。代入式 (5.27)，复杂度项至多为 $\frac{2}{\rho} \sqrt{2d \log(en/d)/n}$ 。若 VC 维无限，这一替换不能使用，但原始的经验 ρ Rademacher 上界仍然有效；此时需要实际得到较小的复杂度，才能给出有用的期望风险保证。

式 (5.27) 没有显式出现基假设的个数 T 。因此，在基假设空间固定时，增加轮次若能改善样本上的归一化间隔，可能使这个期望风险上界减小。它并不保证增加轮次一定改善间隔，也不保证所有集成模型都优于单个模型。集成学习的统计保证需要同时检查组合方式、基假设的复杂度，以及样本上的错误或间隔；它的计算代价还取决于训练轮数和每个基假设的训练、预测时间。

5.7 可计算 PAC 学习

前面的统计结论说明，在样本足够多时，某种学习规则能够输出期望风险较小的假设。但是， $\arg \min_{h \in \mathcal{H}} \hat{R}_S(h)$ 只是指定了要找什么，并没有说明如何找到它。同样，VC 维有限并不自动提供寻找假设的程序，压缩方案的存在也不保证压缩能够快速完成。要把统计保证变成可运行的学习算法，需要分别考察程序是否能够完成计算，以及完成计算需要多少资源。

5.7.1 统计保证与程序实现

讨论计算之前，必须说明数据与假设怎样交给计算机。例如，布尔向量可用有限比特串表示，自然数可用二进制表示；实数输入则需要另行约定有理数编码、精度或访问模型。输入维数相同而数值编码长度不同，计算代价也可能不同，因此不能只用样本个数衡量运行时间。本节关于可计算性的结论使用 $X = \mathbb{N}$ ，假设以能对每个输入停机并输出 0 或 1 的程序表示。关于高效学习的例子则使用有限维布尔输入。

定义 5.24 可计算 PAC 学习 设 $\mathcal{H} \subseteq \{0, 1\}^{\mathbb{N}}$ 。若存在一个对每份有限带标签样本 S 都停机的程序 A ，输出一个总可计算二分类假设的程序编码，并且对任意 $\varepsilon, \delta \in (0, 1)$ 存在有限的 $m(\varepsilon, \delta)$ ，使所有 $n \geq m(\varepsilon, \delta)$ 及所有分布 $\mathcal{P}$ 均满足

$$\mathbb{P}_{S \sim \mathcal{P}^n} \left\{ R_{\mathcal{P}}(A(S)) \leq \inf_{h \in \mathcal{H}} R_{\mathcal{P}}(h) + \varepsilon \right\} \geq 1 - \delta,$$

则称 $\mathcal{H}$ 是不可知 **可计算 PAC 可学习的** (computably PAC learnable, CPAC)。将分布限制为 $\mathcal{H}$ 可实现分布，并将右侧风险要求改为 $R_{\mathcal{P}}(A(S)) \leq \varepsilon$ ，得到可实现版本。

“总可计算”意味着预测程序对每个自然数输入都停机。若还要求 $A(S) \in \mathcal{H}$ ，则是恰当学习；允许输出其他可计算假设，则是非恰当学习。定义要求存在足够大的样本量，但没有要求程序能根据 ε, δ 算出一个足够的样本量。当样本量上界本身也要求可计算时，文献称之为 strong CPAC。这一术语中的 strong 指样本量上界的有效性，与集成学习中将弱优势提升到任意精度的“强学习”含义不同。

对于有限且给定可执行列表的假设空间，可以逐个计算经验风险，再输出经验风险最小者。问题出现在无限假设空间：即使能够依次列出所有假设，也未必知道何时已经检查完所有可能更好的假设。特别是在有噪声时，当前最小经验风险仍可能被后续假设改进。因此，“可以枚举假设”和“可以计算 ERM”是不同条件。

定理 5.25 可计算 ERM 给出的学习保证 设 $\mathcal{H} \subseteq \{0, 1\}^{\mathbb{N}}$ 的 VC 维 d 有限。若存在对所有有限带标签样本都停机的程序，输出 $\mathcal{H}$ 中一个可有效求值的经验风险最小化假设，则 $\mathcal{H}$ 恰当地不可知 CPAC 可学习，且具有可计算的样本量上界。

证明. 令 A 为给定 ERM 程序。有限 VC 维给出分布无关的一致收敛样本量上界；将精度设为 $\varepsilon/2$ ，在一致收敛事件上，对任意 $h \in \mathcal{H}$ 有

$$R_{\mathcal{P}}(A(S)) \leq \hat{R}_S(A(S)) + \varepsilon/2 \leq \hat{R}_S(h) + \varepsilon/2 \leq R_{\mathcal{P}}(h) + \varepsilon.$$

对 h 取下确界得到所需保证。VC 一致收敛上界是 d, ϵ, δ 的显式函数，所以对固定假设空间，将一个有限的 VC 维上界作为常数写入程序，就能计算足够的样本量。训练程序与输出假设的可计算性则由题设保证。 ■

证明中使用已知的有限维度上界，并不意味着能从任意假设空间的程序描述中自动算出 VC 维。这个区别体现了统计存在性与统一算法构造之间的差距。

5.7.2 有效 VC 维

普通 VC 维为 d 意味着：任取 $d+1$ 个不同输入，总有一种 0/1 预测不能由假设空间实现。这个结论只断言这样的预测存在。对计算机而言，还需要一套步骤，能够读入这些输入，在有限时间内找出一组不能实现的预测。

有效 VC 维 (effective VC dimension) 把这一寻找过程加入维度条件。

定义 5.26 有效 VC 维 对 $\mathcal{H} \subseteq \{0, 1\}^{\mathbb{N}}$ ，若存在总可计算映射 W ，使任意 $d+1$ 个互异输入 $x_1, \dots, x_{d+1}$ 都满足

$$W(x_1, \dots, x_{d+1}) \in \{0, 1\}^{d+1} \setminus \{(h(x_1), \dots, h(x_{d+1})) : h \in \mathcal{H}\},$$

则称 d 为有效 VC 维的一个上界。所有这样的非负整数 d 中的最小值记为 $\text{eVC}(\mathcal{H})$ ；若不存在，则记为 ∞ 。

映射 W 只需给出一种不可能的预测，无须列出所有可能预测。对自然数上的递增阈值，给定两个不同输入，比较大小后令较小者对应 1、较大者对应 0，就得到无法实现的预测。这个程序总能停机，因此有效 VC 维至多为 1。单个输入又可分别预测为 0 或 1，所以普通 VC 维和有效 VC 维都为 1。

定理 5.27 普通 VC 维与有效 VC 维的比较 对非空 $\mathcal{H} \subseteq \{0, 1\}^{\mathbb{N}}$ ， $\text{VC}(\mathcal{H}) \leq \text{eVC}(\mathcal{H})$ 。若普通 VC 维有限，且 $\mathcal{H}$ 具有定理 5.25 所述的可计算 ERM，则两者相等。

证明. 若有效 VC 维至多为 d ，见证程序对任意 $d+1$ 个输入都会给出一个不能实现的预测，所以这些输入不可能被打散，普通 VC 维至多为 d 。

再设普通 VC 维为 $d < \infty$ 。给定 $d+1$ 个不同输入，枚举全部 2^{d+1} 种 0/1 赋值，对每一份相应带标签样本运行 ERM 并计算其经验风险。每次计算都停机，且至少有一种赋值不能被任何 $h \in \mathcal{H}$ 完全实现。该赋值的最小经验风险大于零，因此 ERM 输出也具有正经验风险。返回首次发现的这种赋值，就构造了有效见证程序。故有效 VC 维至多为 d ，结合前一方面得证。 ■

有效 VC 维还给出非恰当可计算学习的完整刻画。在上述自然数输入、以总可计算函数为输出的模型中, Delle Rose 等证明: 非恰当不可知 CPAC 可学习, 当且仅当有效 VC 维有限⁸。这一结果需要构造适当的可计算学习器, 不能仅由普通 VC 维的一致收敛证明推出。这里给出刻画以说明有效维度的作用; 其完整计算论证明见原文。

允许非恰当输出是这条刻画的条件。若额外要求输出始终属于原假设空间, 就不能直接沿用结论; 样本量上界是否可计算也可能产生区别。有关研究构造了普通 VC 维有限、却不存在非恰当 CPAC 学习器的假设空间, 说明即使统计上的样本数量不是障碍, 程序实现仍可能成为障碍⁹。这类不可计算性也不同于下一小节的运行时间问题。

5.7.3 高效学习与优化误差

一个程序最终停机, 仍可能需要无法承受的时间。高效 PAC 学习在可计算性的基础上, 要求样本量、训练时间和预测时间受多项式控制。讨论一族问题时, 要明确多项式的变量: 通常包括输入维数或问题规模 p 、输入和输出的编码长度、 $1/\epsilon$ 以及 $\log(1/\delta)$; 具体表示模型还可能引入目标假设的描述长度。把一次实数运算当成一步, 与按比特计费, 是不同的计算模型, 不能混用。

统计分析也不一定要求精确求解 ERM。允许算法输出经验风险只比最优值大 α 的假设, 可以把求解精度与样本估计精度分别控制。

定理 5.28 近似 ERM 的期望风险保证 设 $A(S) \in \mathcal{H}$, 且 $\hat{R}_S(A(S)) \leq \inf_{h \in \mathcal{H}} \hat{R}_S(h) + \alpha$ 。若样本满足 $\sup_{h \in \mathcal{H}} |R_{\mathcal{P}}(h) - \hat{R}_S(h)| \leq \eta$, 则

$$R_{\mathcal{P}}(A(S)) \leq \inf_{h \in \mathcal{H}} R_{\mathcal{P}}(h) + 2\eta + \alpha.$$

证明. 对任意 $h \in \mathcal{H}$, 依次使用一致收敛、近似最优性及一致收敛, 得到

$$R_{\mathcal{P}}(A(S)) \leq \hat{R}_S(A(S)) + \eta \leq \hat{R}_S(h) + \alpha + \eta \leq R_{\mathcal{P}}(h) + \alpha + 2\eta.$$

对 h 取下确界即得结论。 ■

这里 2η 来自经验风险与期望风险的偏差, α 来自优化没有精确求解。例如取 $\eta = \epsilon/4$ 、 $\alpha = \epsilon/2$, 就能将总的超额期望风险控制在 ϵ 以内。若获得这种近似解的时间和所需样本量都是所约定参数的多项式, 就得到高效不可知 PAC 学习的一条充分途径。相反, 某个精确 ERM 问题难求解, 尚不足以证明所有近似或非恰当学习器都不高效。

⁸ V. Delle Rose, A. Kozachinskiy, C. Rojas, T. Steifer, *Find a Witness or Shatter: The Landscape of Computable PAC Learning* In Proceedings of the 36th Conference on Learning Theory, 2023, pp. 511–524

⁹ V. Delle Rose, A. Kozachinskiy, C. Rojas, T. Steifer, *Find a Witness or Shatter: The Landscape of Computable PAC Learning* In Proceedings of the 36th Conference on Learning Theory, 2023, pp. 511–524

5.7.4 从枚举到有效算法

布尔合取展示了统计复杂度与计算方法的区别。输入为 $\mathbf{x} \in \{0, 1\}^p$ ，一个文字是 x_j 或其否定 $1 - x_j$ ；合取假设在所有选中文字均为 1 时预测 1，否则预测 0。每个坐标可选择正文字、负文字或不使用，所以不含矛盾文字的合取至多有 3^p 个。再加入恒为 0 的假设，得到有限假设空间 $\mathcal{C}_p$ 。有限假设空间的可实现样本量界因而只按 p 线性增长，但逐个枚举这些假设需要检查指数数量的候选。枚举很慢只是这种求解方法的性质。

在可实现设定下，可以直接构造与样本一致的合取：初始保留全部 $2p$ 个文字，每遇到一个标签为 1 的样本，就删除在它上面取值为 0 的文字。处理完所有正例后，输出剩余文字的合取；没有剩余文字时输出恒为 1。若没有正例，则输出恒为 0。

定理 5.29 布尔合取的高效可实现学习 上述算法在 $\mathcal{C}_p$ 可实现的样本上输出与样本一致的假设，训练时间为 $O(np)$ ，预测时间为 $O(p)$ 。对于 $\varepsilon, \delta \in (0, 1)$ ，只要

$$n \geq \frac{\log(3^p + 1) + \log(1/\delta)}{\varepsilon},$$

就以至少 $1 - \delta$ 的概率输出零一损失期望风险不超过 ε 的假设。

证明。若样本没有正例，恒为 0 与样本一致。否则，目标合取中的每个文字都在所有正例上为 1，所以不会被删除。算法保留的每个文字也都在全部正例上为 1，因此输出合取对全部正例。对于任意负例，目标合取中至少有一个文字在该输入上为 0；这个文字仍然被保留，故输出也预测 0。算法因此与全部样本一致。每个样本最多检查 $2p$ 个文字，训练时间为 $O(np)$ ，输出最多含 p 个非矛盾文字，预测时间为 $O(p)$ 。将 $|\mathcal{C}_p| \leq 3^p + 1$ 代入有限假设空间的可实现 PAC 样本量界即得风险保证。 ■

这个例子同时给出了样本量、实际算法和运行时间，而不是只写出一个经验风险最小化目标。它也依赖可实现条件：有噪声时，错误标成正例的观测可能删除目标合取需要的文字，上述一致性证明就失效。改变学习设定后，需要重新分析优化与统计保证。

5.8 本章小结

要判断有限样本能否排除期望风险较高的候选，不能只分析一个事先固定的假设，还必须控制算法看过样本后可能选择的整个假设空间。对有限假设空间，把所有假设的失败概率相加，可以得到可实现与不可知设定下的充分样本量；假设空间无限时，计数对象改为它在有限输入上给出的不同预测。Sauer–Shelah 引理用 VC 维控制这个预测数目，再经对称化建立经

验风险与期望风险的联系。在共享可测性约定及本章列明的条件下，有限 VC 维、一致收敛、可实现 PAC 可学习与不可知 PAC 可学习等价。

可学习性刻画回答是否存在统一的样本量保证，具体期望风险上界还可以利用更多信息。Rademacher 复杂度与高斯复杂度分别用随机正负号和高斯变量衡量函数空间拟合随机波动的能力，样本压缩则利用重构输出所需保留的信息量。集成学习需要同时控制基假设的表达能力、组合方式与训练过程；无限基假设空间并不妨碍学习，但经验风险随轮数下降也不能单独保证期望风险下降。这些分析给出了不同的充分条件，不能只凭表达式较短就认定哪一种总是更紧。

统计维度有限、程序能够实现、运行时间为多项式，是三个不同层次。有效 VC 维与可计算学习器联系起来，高效学习还需核算训练、预测和输出表示的代价。二分类中的这些区别在多分类中仍然存在，但单一维度同时刻画一致收敛与可学习性的等价关系将不再普遍成立。

延伸阅读 若希望进一步推导依赖样本的期望风险上界，可阅读 Bartlett 与 Mendelson 关于 Rademacher 复杂度和高斯复杂度的论文。它不仅给出概率保证，还讨论组合函数空间的复杂度怎样由基函数空间控制，适合接着本章的线性预测与集成学习分析阅读¹⁰。

对样本压缩感兴趣，可以继续阅读 Moran 与 Yehudayoff 关于 VC 假设空间压缩方案的构造。关注点应放在“有限 VC 维为何能保证存在压缩表示”，并与本章“已有压缩表示怎样推出期望风险上界”的证明对照。压缩表示的存在、大小以及能否高效求出仍需分别判断¹¹。

可计算性方向可继续阅读 Delle Rose 等的有效 VC 维刻画，比较普通 PAC、CPAC 与附加可计算样本量要求的版本。这有助于理解为什么统计学习基本定理不能直接充当可执行算法¹²。

¹⁰ P. L. Bartlett, S. Mendelson, *Rademacher and Gaussian Complexities: Risk Bounds and Structural Results* In Journal of Machine Learning Research, 2002, vol. 3, pp. 463–482

¹¹ S. Moran, A. Yehudayoff, *Sample Compression Schemes for VC Classes* In Journal of the ACM, 2016, vol. 63, no. 3, pp. 21:1–21:10

¹² V. Delle Rose, A. Kozachinskiy, C. Rojas, T. Steifer, *Find a Witness or Shatter: The Landscape of Computable PAC Learning* In Proceedings of the 36th Conference on Learning Theory, 2023, pp. 511–524

多分类学习的可学习性

二分类只有两种答案。一个假设在某个输入上改变预测时，改变后的标签已经确定；多分类则允许它改成多个不同标签。这一差别影响了假设空间的计数，也改变了可学习性与一致收敛之间的关系。标签数有限时，关键是把 VC 维的计数方法推广到多分类；标签空间可以无限时，则必须分别分析一致收敛与可学习性。建立这些统计结论后，还要考察学习程序的可计算性需要哪些补充条件。

本章沿用第 4.2 节的分类设定：观测为输入标签对，采用 i.i.d. 抽样与零一损失，并保持风险与 PAC 比较方式不变。变化在于标签空间由 $\{0, 1\}$ 扩展为有限或无限集合 Y 。**图维**（graph dimension）刻画零一损失的一致收敛，**DS 维**（Daniely-Shalev-Shwartz dimension）刻画统计可学习性；在一般多分类中，允许 $\mathcal{W}_{\text{out}}$ 包含 $\mathcal{H}$ 之外的预测器是关键条件。

6.1 从二分类到多分类

以邮件分类为例，标签可以是正常邮件、广告或诈骗。输入 x 仍然表示邮件特征，假设 h 为它选择一个标签；预测标签与真实标签不同，就记一次错误。设输入空间为 X 、标签空间为 Y ，假设空间为非空集合 $\mathcal{H} \subseteq Y^X$ 。对输入与标签的联合分布 $\mathcal{P}$ 以及独立同分布样本 $S = ((x_i, y_i))_{i=1}^n$ ，定义 4.2 与定义 4.3 在零一损失下特化为

$$R_{\mathcal{P}}(h) = \mathbb{P}_{(x,y) \sim \mathcal{P}}\{h(x) \neq y\}, \quad \hat{R}_S(h) = \frac{1}{n} \sum_{i=1}^n \mathbb{I}\{h(x_i) \neq y_i\}. \quad (6.1)$$

本章的风险均使用零一损失。PAC 和不可知 PAC 的成功标准沿用第 4.3 节：前者在可实现分布上要求期望风险足够小，后者要求期望风险接近 $\mathcal{H}$ 所能达到的最低值。以下统计定理均采用第 4.1 节的可测性与可分性约定。

有限个类别确实可以用多个二分类标签的组合来表示。例如，将三类邮件编码为

$$\text{正常} \longleftrightarrow (0, 1), \quad \text{广告} \longleftrightarrow (1, 0), \quad \text{诈骗} \longleftrightarrow (1, 1).$$

这样，一封标为“广告”的邮件就为两个二分类问题分别提供标签 1 和 0。我们用同一批邮件训练两个二分类器 b_1, b_2 ；面对新邮件 x ，先得到 $(b_1(x), b_2(x))$ ，再按编码表还原类别。若得到未使用的编码 $(0, 0)$ ，可以约定输出一个固定类别，例如正常邮件。这里把一个三分类问题转成了两个二分类问题，并没有减少需要辨认的类别信息。

这种做法可以推广到任意有限标签空间。若 $|Y| = K$ ，用 $L = \lceil \log_2 K \rceil$ 个二进制位就足以给所有类别分配不同编码。记编码为 $c : Y \rightarrow \{0, 1\}^L$ ，第 j 位为 $c_j(y)$ 。原多分类假设空间 $\mathcal{H}$ 在这一位上诱导的二分类假设空间是

$$\mathcal{B}_j = \{x \mapsto c_j(h(x)) : h \in \mathcal{H}\}, \quad 1 \leq j \leq L.$$

这个式子说明二分类子问题的假设从哪里来：把每个多分类假设的输出标签换成编码，再只保留第 j 位。标签虽然变成了 0 和 1， $\mathcal{B}_j$ 本身仍可能很复杂；二分类理论要求它具有有限 VC 维，才保证分布无关的 PAC 可学习性。编码本身不会自动满足这个要求。

在可实现情形，如果每个 $\mathcal{B}_j$ 都 PAC 可学习，这一归约就能给出多分类保证。设学到的第 j 个二分类器的期望风险为

$$e_j = \mathbb{P}_{(x,y) \sim \mathcal{P}} \{b_j(x) \neq c_j(y)\}.$$

令 $\tilde{h}$ 表示编码还原后的分类器。当所有位都预测正确时， $\tilde{h}$ 必然输出真实类别。因此，多分类预测错误只能发生在至少一位预测错误时，从而

$$R_{\mathcal{P}}(\tilde{h}) \leq \sum_{j=1}^L e_j.$$

把各二分类器的期望风险分别控制在 ε/L 以内，各自学习失败的概率分别控制在 δ/L 以内，就能以至少 $1 - \delta$ 的概率保证 $R_{\mathcal{P}}(\tilde{h}) \leq \varepsilon$ 。各二分类器可以使用同一批样本，这里不要求它们的错误相互独立；合成后的分类器也未必属于原假设空间。

不可知情形则不能仅凭“每一位都学到最优”得到原多分类问题的最优期望风险。仍用上面的编码，假设输入只有一个值，三类标签出现的概率依次为 0.40, 0.35, 0.25，并允许三个常量多分类假设。第一位取 1 的概率为 0.60，第二位取 1 的概率为 0.65，所以两个最优二分类器都预测 1，合成后始终预测诈骗，期望风险为 0.75。但始终预测正常的多分类假设具有更小的期望风险 0.60。这里每一位的最优预测已经知道，即使样本无限多，逐位优化仍然选错了最优类别。原因是逐位学习分别比较各位的错误比例，而多分类零一损失比较的是整个类别是否正确。

因此，二进制编码提供了有限标签下的一种算法构造方法；要建立学习保证，还需分析编码诱导的二分类假设空间，并把各位的期望风险转换为

多分类期望风险。标签无限时，任何固定长度的二进制编码都无法区分所有类别，上面的有限次归约也就不能直接使用。为了统一讨论有限和无限标签，并直接判断原假设空间的可学习性，我们还需要研究多分类假设在一组输入上能够实现哪些预测。

直接分析多分类假设空间时，也不能简单要求它在 m 个输入上实现全部 $|Y|^m$ 种预测。例如，一个假设空间可能只使用每个输入处的两个标签，却已经包含任意大的二分类问题。若要求使用全部标签才算打散，就会漏掉这种困难。合理的推广应允许各输入只在两个预先指定的标签之间切换。**Natarajan 维** (Natarajan dimension) 刻画能够保持这种独立二元选择的输入规模上限。

6.2 有限标签空间

本节固定 $2 \leq K = |Y| < \infty$ 。先找出多分类中的二元选择结构，再用它限制有限输入上的预测数目，就能沿用前章从一致收敛到 ERM 泛化的证明。

6.2.1 Natarajan 维

Natarajan 打散的有限模式例和图已经放在第一卷“数学准备”的“计数与计算”章：两个输入分别固定“正常、广告”和“正常、诈骗”两组标签，四个函数实现全部逐点选择。每个输入处的标签对可以不同，但固定后不能随待实现的模式改变。

定义 6.1 Natarajan 打散与 Natarajan 维 设 $C = \{x_1, \dots, x_m\} \subseteq X$ 。若存在 $f, g : C \rightarrow Y$ ，满足 $f(x) \neq g(x)$ 对所有 $x \in C$ 成立，且对每个 $B \subseteq C$ 都存在 $h_B \in \mathcal{H}$ 使

$$h_B(x) = \begin{cases} f(x), & x \in B, \\ g(x), & x \in C \setminus B, \end{cases} \quad (6.2)$$

则称 C 被 $\mathcal{H}$ **Natarajan 打散** (Natarajan shattering)。令 $\mathcal{C}_N$ 为所有被 $\mathcal{H}$ Natarajan 打散的有限输入集组成的集合，定义

$$d_N(\mathcal{H}) = \sup_{C \in \mathcal{C}_N} |C|.$$

这个定义也适用于无限标签空间。当 $|Y| = 2$ 时，每个输入上的不同标签对只能是那两个二分类标签，所以 Natarajan 维就是 VC 维。维度为零表示每个输入上的预测都唯一；可打散的有限点集大小没有上界时，维度为无穷。

该例还加入第三个始终预测为正常的输入：前两个输入给出 $d_N \geq 2$ ，任

何包含第三个输入的集合都不能在该处选择两个标签，而输入空间只有三点，故 $d_N \leq 2$ 。第一卷的图将这两个方向的见证同时画出；这里使用所得维度进入有限标签的预测计数。

6.2.2 有限标签的一致收敛

固定 m 个输入后，不同假设可能给出相同的预测向量。记

$$V(x_1, \dots, x_m) = \{(h(x_1), \dots, h(x_m)) : h \in \mathcal{H}\}.$$

生长函数取所有输入选择中最大的预测数目，即

$$\Pi_{\mathcal{H}}(m) = \sup_{(x_1, \dots, x_m) \in X^m} |V(x_1, \dots, x_m)|.$$

这与第 5.3.2 节的二分类生长函数是同一个计数问题：固定输入，合并给出相同预测的假设，再对输入的选择取最大值。区别只是预测向量的每个坐标现在可以取 K 个标签。二分类的 Sauer–Shelah 引理用 VC 维限制预测数目；下面的定理用 Natarajan 维完成对应的多分类计数。

定理 6.2 有限标签的预测数目上界 设标签数为 $K < \infty$ ，Natarajan 维为 $d < \infty$ 。记 $q = K(K-1)/2$ 为不同标签对的数目，则

$$\Pi_{\mathcal{H}}(m) \leq G_{d,K}(m) := \sum_{j=0}^{\min\{d,m\}} \binom{m}{j} q^j.$$

证明. 对任意有限预测集合 $V \subseteq Y^m$ ，删去最后一个坐标后得到前缀集合 U 。若某个前缀能够接上 r 种末尾标签，它对 $|V|$ 的贡献为 r ，对 $|U|$ 的贡献为 1。把多出的 $r-1$ 次计数分配给标签对，因为 $r-1 \leq r(r-1)/2$ ，得到

$$|V| \leq |U| + \sum_{\{a,b\} \subseteq Y} |U_{a,b}|,$$

其中 $U_{a,b}$ 表示既能接上 a 又能接上 b 的前缀集合。 U 的 Natarajan 维至多为 d ；每个 $U_{a,b}$ 的 Natarajan 维至多为 $d-1$ ，否则把最后一个坐标上的标签对 (a,b) 加入，就会在 V 中打散 $d+1$ 个坐标。

因此最大预测数满足递推上界

$$M(m, d) \leq M(m-1, d) + qM(m-1, d-1).$$

零个坐标只有一个空预测，维度为零时也至多有一个预测向量。对 m 归纳，并使用二项式系数的递推关系，即得所列求和式。 ■

当 $K=2$ 时， $q=1$ 且 $d_N = \text{VC}(\mathcal{H})$ ，定理中的求和式恰好变为二分类

Sauer–Shelah 引理的 $\sum_{j=0}^{\min\{d,m\}} \binom{m}{j}$ 。多分类中额外的 q^j 反映了每个参与二元选择的坐标还可以选择不同的标签对。

对固定 d, K , 这个上界随 m 至多按多项式增长。由于样本标签固定后, 相同的预测向量必然产生相同的零一损失向量, 因此这个计数也控制经验风险的可能取值。前章的副样本和随机交换分析便可用于多分类。

定理 6.3 有限标签的一致收敛保证 在前一定理条件下, 对任意 $\delta \in (0, 1)$ 和 $S \sim \mathcal{P}^n$, 以至少 $1 - \delta$ 的概率,

$$\sup_{h \in \mathcal{H}} |R_{\mathcal{P}}(h) - \hat{R}_S(h)| \leq \sqrt{\frac{8}{n} \log \frac{4G_{d,K}(2n)}{\delta}}. \quad (6.3)$$

证明. 令 $\eta > 0$ 且 $n\eta^2 \geq 2$ 。引入独立副样本后, 对称化把期望风险与经验风险的偏差事件, 转化为两份经验风险相差超过 $\eta/2$ 的事件, 概率至多增加一倍。在合并的 $2n$ 个输入上, 不同损失向量至多有 $G_{d,K}(2n)$ 种。随机交换每对观测, 对每个固定向量使用 Hoeffding 不等式, 再把这些概率相加, 得到

$$\mathbb{P} \left\{ \sup_h |R_{\mathcal{P}}(h) - \hat{R}_S(h)| > \eta \right\} \leq 4G_{d,K}(2n)e^{-n\eta^2/8}.$$

令右侧为 δ 便得到结论; 所得 η 自动满足 $n\eta^2 \geq 2$ 。若上界大于 1, 则由零一损失取值范围直接成立。 ■

这里的分布是 $X \times Y$ 上的联合分布, 并未要求类别出现概率相同。固定 d, K, δ 后, 式 (6.3) 趋于零, 且同一个样本量适用于所有允许分布, 这正是分布无关的一致收敛。例如, $1 \leq d \leq 2n$ 时可用 $G_{d,K}(2n) \leq q^d(2en/d)^d$ 进一步估计右侧, 看到类别数通过 $\log K$ 影响这个上界。

6.2.3 有限标签的可学习性

一致收敛保证每个假设的经验风险都接近其期望风险, 因此 ERM 在样本上的选择也能得到期望风险保证。结合 Natarajan 打散所给出的不可学习性下界, 可以得到以下等价关系。

定理 6.4 有限标签的可学习性刻画 若 $2 \leq |Y| = K < \infty$, 则以下命题等价:

1. $d_N(\mathcal{H}) < \infty$;
2. 零一损失满足分布无关的一致收敛;

3. $\mathcal{H}$ 不可知 PAC 可学习;

4. $\mathcal{H}$ 可实现 PAC 可学习。

设 $d = d_N(\mathcal{H}) < \infty$ 。对任意 $\varepsilon, \delta \in (0, 1)$, 若

$$n \geq \frac{32}{\varepsilon^2} \log \frac{4G_{d,K}(2n)}{\delta},$$

则任意 ERM 以至少 $1 - \delta$ 的概率满足

$$R_{\mathcal{P}}(A(S)) \leq \inf_{h \in \mathcal{H}} R_{\mathcal{P}}(h) + \varepsilon.$$

证明. 有限 Natarajan 维推出前一定理的一致收敛。令其精度为 $\varepsilon/2$, 对任意比较假设 h , 有

$$\begin{aligned} R_{\mathcal{P}}(A(S)) &\leq \hat{R}_S(A(S)) + \varepsilon/2 \\ &\leq \hat{R}_S(h) + \varepsilon/2 \\ &\leq R_{\mathcal{P}}(h) + \varepsilon. \end{aligned}$$

对 h 取下确界得到不可知 PAC 保证, 而它当然涵盖可实现分布。

反过来, 若 Natarajan 维无限, 对任意 n 都能找到 $2n$ 个被打散的输入, 并在每个输入处固定两个不同标签。令输入均匀分布, 目标在每对标签中独立等概率选择。 n 次抽样至多看到 n 个不同输入; 每个未见输入处的两个标签仍等可能, 因此任意学习器对随机目标的平均期望风险至少为 $1/4$ 。于是存在一个固定的可实现目标, 使算法的平均期望风险至少为 $1/4$ 。由 $R \leq 1$, 有 $\mathbb{E}R \leq 1/8 + (7/8)\mathbb{P}\{R > 1/8\}$, 故失败概率至少为 $1/7$ 。这对每个 n 都成立, 否定了分布无关的可实现 PAC 保证。■

最后一段证明并未使用标签数有限, 因此有限 Natarajan 维对任意标签空间都是可学习性的必要条件。有限标签条件用于相反方向的预测计数。上面的 ERM 样本量是一个充分条件, 并不声称它给出了可实现或不可知学习的最优样本复杂度。

6.2.4 Natarajan 维在无限标签空间下的局限

当 Y 无限时, 前面的 $q = \binom{K}{2}$ 不再有限, 预测计数不能沿原样使用。这只是证明方法失效, 还不足以说明 Natarajan 维本身失效。要否定它的充分性, 必须找到 Natarajan 维有限但不可学习的假设空间。

一个二维例子可以先展示 Natarajan 维遗漏了什么。考虑两个输入上的

六种预测

$$(a, u), (b, u), (b, v), (c, v), (c, w), (a, w),$$

其中 a, b, c 互异, u, v, w 互异。固定任意一个预测, 都能只改第一坐标得到另一个, 也能只改第二坐标得到另一个。例如 (a, u) 有邻居 (b, u) 和 (a, w) 。但任何两个第一坐标标签至多共享一个第二坐标标签, 因此找不到两对标签构成全部四种组合。这个预测集合的 Natarajan 维为 1, 却在两个坐标上都持续保留了局部歧义。单个有限例子本身仍然可学习; 真正的反例需要任意高维的这种结构。

把二维例子推广到任意维, 需要下面的组合构造。引理中将 V_m 的每个向量视为定义在坐标集合 $\{1, \dots, m\}$ 上的预测函数, 因此可以讨论它的 Natarajan 维。

引理 6.5 低 Natarajan 维的局部邻接构造 对每个整数 $m \geq 1$, 存在有限标签集 Y_m 及有限非空集合 $V_m \subseteq Y_m^m$, 使

1. $d_N(V_m) = 1$;
2. 对任意 $v \in V_m$ 和 $i \in \{1, \dots, m\}$, 存在 $u \in V_m$ 满足

$$u_i \neq v_i, \quad u_j = v_j \quad (j \neq i).$$

该引理引用 Brukhim 等的组合拓扑构造¹。本章不展开其构造证明。第一条限制预先固定标签对的二元选择, 第二条却保证每个预测在每个坐标上都有竞争者。下面以这两条性质为依据, 构造一个固定的不可学习假设空间。

定理 6.6 无限标签下有限 Natarajan 维并不充分 存在可数输入空间、可数标签空间和假设空间 $\mathcal{H}$, 使 $d_N(\mathcal{H}) = 1$, 但 $\mathcal{H}$ 不是可实现 PAC 可学习的。

证明. 取引理 6.5 中的 V_m , 令输入空间为互不相交的有限块 $X = \bigcup_{m \geq 1} C_m$, 其中 $C_m = \{(m, 1), \dots, (m, m)\}$ 。对每个局部标签 $y \in Y_m$, 用 (m, y) 表示带有块编号的标签。例如, $(2, a)$ 和 $(3, a)$ 是两个不同类别, 即使它们都包含字母 a 。还需要一个单独的类别, 表示“输入不在这个假设所选的块内”。把这个类别记为 $\star$, 并约定它不等于任何 (m, y) 。它是一个普通的预测标签, 不表示未知标签、缺失值或任意取值。完整标签空间为

$$Y = \{\star\} \cup \bigcup_{m \geq 1} (\{m\} \times Y_m).$$

¹ N. Brukhim, D. Carmon, I. Dinur, S. Moran, A. Yehudayoff, *A Characterization of Multiclass Learnability* In Proceedings of the 63rd Annual Symposium on Foundations of Computer Science, 2022, pp. 943–955

对 $v \in V_m$, 定义

$$h_{m,v}(r, i) = \begin{cases} (m, v_i), & r = m, \\ \star, & r \neq m. \end{cases}$$

因此, $h_{2,v}$ 在块 C_2 内使用 v 给出的局部标签, 在 C_1, C_3 等所有其他块上都输出同一个“块外”类别 $\star$ 。这样每个局部向量都被扩展成整个输入空间上的假设。令 $\mathcal{H}$ 由所有这些 $h_{m,v}$ 组成。

两个来自不同块的输入不能被 Natarajan 打散: 每个标签对至少有一个非 $\star$ 标签, 但没有假设能同时在两个块上输出非 $\star$ 标签。同一块内的两个输入也不能被打散: 若标签对包含 $\star$, 一处输出 $\star$ 就迫使该块所有位置输出 $\star$, 不能独立选择; 若两对都不包含 $\star$, 则会要求 V_m 打散两个坐标, 与其 Natarajan 维为 1 矛盾。某个输入又能取局部标签或 $\star$, 所以 $d_N(\mathcal{H}) = 1$ 。

给定任意样本量 n , 取 $m = 2n$, 令输入均匀分布于 C_m , 目标向量从 V_m 均匀选择。对于样本中未出现的坐标 i , 即使额外告知学习器其余全部坐标的真实标签, 第 i 个坐标仍至少有两个等可能的候选标签: 这些候选对应 V_m 中与其坐标相同的向量, 每个向量的先验权重相同, 且邻居条件保证候选数至少为 2。所以学习器在这个坐标上的平均错误概率至少为 $1/2$ 。

至少一半输入未在样本中出现, 故对随机目标、样本及学习器随机性的平均期望风险至少为 $1/4$ 。对目标取平均意味着存在一个固定 $v \in V_m$ 也达到这个下界。与前一定理相同, 期望风险超过 $1/8$ 的概率至少为 $1/7$ 。每个 n 都有这样的可实现分布, 因而不存在分布无关的 PAC 样本量保证。■

障碍不在于标签无限就无法学习, 而在于有限 Natarajan 维没有排除所有困难的预测结构。接下来需要分别刻画两件事: 整个假设空间是否一致收敛, 以及是否存在能够学习它的算法。

6.3 无限标签空间

有限标签时, Natarajan 维通过生长函数把一致收敛与可学习性联系起来。第 6.2.4 节说明, 去掉标签数有限这一条件后, 有限 Natarajan 维已经不足以保证学习成功。此时还要区分两个问题: 所有假设的经验风险能否同时准确估计各自的期望风险, 以及是否存在一个算法能够选出期望风险足够小的假设。前者要求整个假设空间都受到控制, 后者只要求算法作出合适的选择。

这两个问题需要不同的维度。一致收敛关注预测相对于真实标签是否正确, 因而可以通过图维转化为二值损失函数的 VC 维问题。可学习性则还要考虑标签本身携带的信息, DS 维通过预测之间只改变一个输入的关系, 刻画有限样本无法排除的预测歧义。下面先证明图维与一致收敛的关系。

系，再说明为何可学习性需要单独分析。

6.3.1 一致收敛

期望风险只关心预测是否等于真实标签。即使错误标签有无限种，零一损失仍只有 0 和 1。因此可以为每个输入固定一个参考标签，再考察假设能否独立决定在哪些输入上与它相同。这种结构称为**图打散** (graph shattering)，图维记录能够保持这些独立选择的输入规模上限。

定义 6.7 图打散 若有限集 $C \subseteq X$ 存在 $f : C \rightarrow Y$ ，使每个 $B \subseteq C$ 都对应某个 $h_B \in \mathcal{H}$ ，满足

$$h_B(x) = f(x) \ (x \in B), \quad h_B(x) \neq f(x) \ (x \in C \setminus B),$$

则称 C 被 $\mathcal{H}$ 图打散。

图打散描述一个给定点集上的预测能力。与 VC 维和 Natarajan 维一样，把可被打散的点集大小取上确界，就得到整个假设空间的维度。

定义 6.8 图维 设 $\mathcal{C}_G$ 为所有被 $\mathcal{H}$ 图打散的有限输入集组成的集合，定义

$$d_G(\mathcal{H}) = \sup_{C \in \mathcal{C}_G} |C|.$$

图打散只固定一个参考标签；不等于它时可以使用任何标签，而且可以随 B 改变。Natarajan 打散则事先固定替代标签。因此，Natarajan 打散总能给出图打散，反过来不一定。

第一卷“计数与计算”章还给出图维恰为 2 的四函数例：前两个输入相对于固定基准实现全部匹配或不匹配组合，第三个输入保持不变；偏离基准时采用的标签并不固定。本章据此只保留图维怎样进入零一损失一致收敛的论证。

为把多分类损失化为二分类函数，令 $\mathcal{L}_{\mathcal{H}} = \{(x, y) \mapsto \mathbb{I}\{h(x) \neq y\} : h \in \mathcal{H}\}$ 。它的定义域是输入与标签的二元组，而输出只有 0 或 1。

定理 6.9 图维与一致收敛 对任意标签空间， $\text{VC}(\mathcal{L}_{\mathcal{H}}) = d_G(\mathcal{H})$ 。因此，零一损失的分布无关一致收敛当且仅当 $d_G(\mathcal{H}) < \infty$ 成立。

证明. 若 C 被以 f 为参考图打散，则在点集 $\{(x, f(x)) : x \in C\}$ 上，损失函数能够实现所有 0/1 预测，故损失函数空间的 VC 维至少为图维。

反过来，若一组 (x_i, y_i) 被损失函数空间打散，它不能包含同一个输入

对应两个不同标签的点, 否则无法让两个损失同时为 0。于是所有 x_i 互异; 令 $f(x_i) = y_i$, 损失取 0 与 1 分别对应预测等于和不等 $f(x_i)$, 所以这些输入被图打散。两种维度相等。由前章的 VC 一致收敛定理, 二值损失函数空间满足分布无关的一致收敛, 当且仅当它的 VC 维有限, 因此得到所述等价关系。 ■

图维解决了经验风险能否同时准确估计所有假设期望风险的问题。在这个保证下, ERM 选择经验风险最小的假设, 就能得到接近假设空间最优期望风险的预测结果。下面单独给出这一推论及其误差比较过程。

定理 6.10 一致收敛推出可学习性 设 $\mathcal{H}$ 在零一损失下满足分布无关的一致收敛。对任意 $\varepsilon, \delta \in (0, 1)$, 若样本量 n 足以使任意联合分布 $\mathcal{P}$ 下的样本 $S \sim \mathcal{P}^n$ 满足

$$\mathbb{P}\left\{\sup_{h \in \mathcal{H}} |\hat{R}_S(h) - R_{\mathcal{P}}(h)| \leq \varepsilon/2\right\} \geq 1 - \delta,$$

则任意 ERM 学习算法 A 均以至少 $1 - \delta$ 的概率满足

$$R_{\mathcal{P}}(A(S)) \leq \inf_{h \in \mathcal{H}} R_{\mathcal{P}}(h) + \varepsilon.$$

因此, $\mathcal{H}$ 不可知 PAC 可学习, 也可实现 PAC 可学习。

证明. 考虑所有假设的经验风险与期望风险之差均不超过 $\varepsilon/2$ 的样本事件。它的概率至少为 $1 - \delta$, 且其中的估计保证也适用于依赖样本选出的 $A(S)$ 。对任意 $h \in \mathcal{H}$, 有

$$\begin{aligned} R_{\mathcal{P}}(A(S)) &\leq \hat{R}_S(A(S)) + \varepsilon/2 \\ &\leq \hat{R}_S(h) + \varepsilon/2 \\ &\leq R_{\mathcal{P}}(h) + \varepsilon. \end{aligned}$$

第一步和第三步分别使用 $A(S)$ 与 h 的估计保证; 第二步使用 ERM 的经验风险最小性。对 h 取下确界就得到不可知 PAC 的期望风险保证。由于一致收敛所需的样本量不依赖具体的 $\mathcal{P}$, 这个学习保证也是分布无关的。可实现情形下, 假设空间的最小期望风险为零, 结论进一步成为 $R_{\mathcal{P}}(A(S)) \leq \varepsilon$ 。 ■

结合这两个定理, 有限图维足以保证可学习。但在无限标签下, 有限图维不再是可学习的必要条件。

一致收敛足以保证 ERM 学习, 但它要求同时控制所有假设。以下例子中, 标签本身能够帮助算法识别目标假设, 因而即使整个假设空间不一致收敛, 仍然可以学习。

令 $X = \mathbb{N}$ 。每个自然数的有限子集都作为一个标签，另设一个与所有集合标签不同的类别 $\star$ 。在本例中，它表示“输入不属于目标集合”，同样不是未知或缺失标签。对每个有限 A 定义

$$h_A(x) = \begin{cases} A, & x \in A, \\ \star, & x \notin A, \end{cases} \quad \mathcal{H}_C = \{h_A : A \subset \mathbb{N} \text{ 有限}\}. \quad (6.4)$$

例如，标签 $\{2, 5\}$ 本身就告知哪些输入属于集合。因此，一旦观察到非 $\star$ 标签，学习器便能恢复整个目标假设；如果样本标签全为 $\star$ ，就输出 $h_\emptyset$ 。这是一种利用标签中信息的数学构造，区别于一般语义类别。

定理 6.11 可学习性不推出一致收敛 $\mathcal{H}_C$ 满足 $d_N = 1$ 及 $d_G = \infty$ 。它可实现 PAC 可学习，但不满足一致收敛，且存在不具有 PAC 保证的 ERM 选择规则。

证明. 设目标为 h_A , $p = \mathcal{P}_X(A)$ 。上述算法见到一次非 $\star$ 标签便具有零期望风险；否则期望风险为 p 。若 $p > \varepsilon$ ，后一事件的概率为 $(1-p)^n \leq e^{-n\varepsilon}$ ，故 $n \geq \log(1/\delta)/\varepsilon$ 足够学习。

任意有限 C 都能以全 $\star$ 为参考被图打散：要恰好在 $B \subseteq C$ 上输出 $\star$ ，选择 $A = C \setminus B$ 即可。因此图维无限，不能一致收敛。另一方面，只要某个输入的预测是非 $\star$ 标签，这个标签就唯一确定整个假设。若两个输入被 Natarajan 打散，其中一个输入的两个标签至少有一个不是 $\star$ 。固定这个非 $\star$ 标签后，另一个输入便无法再自由选择两个标签，产生矛盾。单个输入能够出现两种标签，因此 $d_N = 1$ 。

构造坏 ERM：当大小为 n 的样本标签全为 $\star$ 时，输出 h_{A_S} ，其中 $A_S = \{1, \dots, 2n\} \setminus \{x_1, \dots, x_n\}$ 。其他可实现样本根据非 $\star$ 标签恢复目标；不可实现样本任取经验风险最小者。在全 $\star$ 样本上经验风险为零，但对目标 $h_\emptyset$ 和在 $\{1, \dots, 2n\}$ 上均匀的输入分布，它至少分错 n 个未见输入，期望风险至少为 $1/2$ 。每个 n 都有这样的分布，所以该 ERM 没有分布无关 PAC 保证。 ■

这里的好算法和坏算法都能使可实现样本上的经验风险为零，差别在于如何利用标签信息。这类分离说明，多分类中“存在学习器”不再能通过“所有 ERM 都有保证”替代²。它与第 6.2.4 节的反例作用不同：那里的假设空间没有 PAC 学习器，这里则只有某些 ERM 选择规则失败。

6.3.2 可学习性

集合标签的例子说明，图维无限并不排除存在有效的统计学习方法；另一方面，有限 Natarajan 维也不能保证可学习。要寻找充要条件，需要一种

² A. Daniely, S. Sabato, S. Ben-David, S. Shalev-Shwartz, *Multiclass Learnability and the ERM Principle* In Journal of Machine Learning Research, 2015, vol. 16, no. 72, pp. 2377–2404

比固定标签对更宽泛、又不强求所有假设一致收敛的结构。前面六种预测的例子提供了线索：即使各输入没有固定的两个替代标签，知道其他输入的预测后，仍可能无法确定遗漏输入的预测。

为了精确表达这种歧义，我们要求：集合中的每个预测向量，在每一个坐标上都能找到一个只改变该坐标的预测向量。这种有限预测集合称为**伪立方体**（pseudo-cube）。

定义 6.12 伪立方体 有限非空集合 $V \subseteq Y^m$ 称为 m 维伪立方体，如果对每个 $v \in V$ 和每个 $i \in \{1, \dots, m\}$ ，都存在 $u \in V$ 满足 $u_i \neq v_i$ 且 $u_j = v_j$ 对所有 $j \neq i$ 成立。

六种预测构成二维伪立方体。二分类的全部 2^m 种预测也是 m 维伪立方体，但多分类不要求每个坐标始终只使用两个标签。“有限”是定义的一部分：无限邻接集合可能具有不同性质，不能将这一要求删除。

定义 6.13 DS 维 若 m 个互异输入组成的有序点集 C 满足 $\mathcal{H}|_C$ 包含一个 m 维伪立方体，则称 C 被**DS 打散**（DS shattering）。DS 维 $d_{DS}(\mathcal{H})$ 定义为可被 DS 打散的有限点集大小的上确界。

第一卷把第 6.2.4 节的六种预测画成六环：两种线型分别只改变一个坐标。每个顶点在两个方向上都有邻居，所以它是二维伪立方体；环中没有固定两标签对的四种完整组合，因此 DS 维为 2 而 Natarajan 维为 1。

观察 $m-1$ 个坐标的标签后，若遗漏坐标仍有邻居，就无法仅从其余标签确定它。要求集合中每个向量、每个坐标都有邻居，排除了只在某个特殊向量周围制造少数分支的情况。第一卷的维度对照图汇总了三种观察方式：Natarajan 维固定标签对，图维固定参考标签，DS 维考察逐坐标邻接；其中 DS 栏只表示局部邻接，完整伪立方体还须满足定义中的全体量词。

定理 6.14 多分类维度的比较 对任意标签空间，有 $d_N(\mathcal{H}) \leq d_{DS}(\mathcal{H}) \leq d_G(\mathcal{H})$ 。二分类时三者均等于 VC 维。若 $|Y| = K < \infty$ ，则 $d_N < \infty$ 也蕴含 $d_G < \infty$ 。

证明. Natarajan 打散给出的全部二元选择构成伪立方体，因此第一道不等式成立。对于 m 维伪立方体，固定一个向量 v 作为参考。给定希望改变的坐标集合，逐个沿这些坐标移动到邻居；每一步只改变当前坐标，因此已改变的坐标保持不变，未要求改变的坐标始终与 v 相同。最终向量恰好在指定坐标上不等于 v ，故图打散成立。

二分类中，任何坐标的替代标签唯一，三种结构都要求全部二元预测，所以等于 VC 维。有限标签时，若图打散 m 个输入，至少需要 2^m 个不同

预测向量。由定理 6.2, 当 $d_N = d < \infty$ 时, $2^m \leq G_{d,K}(m)$ 。固定 d, K 后右侧是多项式, 故 m 有有限上界。 ■

更精细地分析最后一个不等式, 可得 $d_G = O(d_N \log K)$; 这里需要标签数有限。对无限标签, 第 6.2.4 节的反例有 $d_N = 1$ 、 $d_{DS} = \infty$, 说明第一道不等式可以相差无穷。前面集合标签的假设空间 $\mathcal{H}_C$ 则满足 $d_{DS} = 1$: 任何出现非 $\star$ 标签的预测向量都唯一确定假设, 因而不可能在另一个坐标方向上拥有邻居; 全 $\star$ 向量独自也不能构成伪立方体。结合单点可以打散可知 DS 维为 1, 而图维无限, 故后一道不等式也不能反向替代。

伪立方体的局部邻居意味着未见坐标仍存在无法从其余标签排除的答案。这一结构可以直接给出学习失败概率的下界。

定理 6.15 无限 DS 维的不可学习性 若 $d_{DS}(\mathcal{H}) = \infty$, 则对每个样本量 n 及任意学习算法, 存在 $\mathcal{H}$ 可实现分布, 使输出假设的期望风险超过 $1/8$ 的概率至少为 $1/7$ 。

证明. 取 $2n$ 个 DS 打散的输入和其上的有限伪立方体 V 。令输入均匀分布, 并从 V 均匀选择目标预测向量, 每个向量选取一个实现它的假设。对未见坐标, 即使知道其余全部标签, 也至少有两个等可能的候选答案, 因此平均错误概率至少为 $1/2$ 。至少一半输入未被观察到, 所以平均期望风险至少为 $1/4$ 。对目标取平均后选出达到该下界的固定目标, 再用 $\mathbb{E}R \leq 1/8 + (7/8)\mathbb{P}\{R > 1/8\}$, 即得结论。 ■

有限 DS 维的充分性需要构造一个学习器, 不能直接使用整个假设空间的一致收敛。Brukhim 等的构造先输出有限的标签列表, 再从列表中选择单个标签; 两步合起来得到一种样本压缩方案。这里先明确引用的构造结论, 再证明它如何给出期望风险保证³。

标签列表是一个映射 μ , 它为每个输入 x 给出有限集合 $\mu(x) \subseteq Y$ 。例如, $\mu(x) = \{\text{正常}, \text{广告}\}$ 表示暂时保留这两个答案。列表覆盖样本, 是指每个样本标签都属于相应列表; 这还不是最终的分类器。构造的第二步利用这些列表重构一个输出单个标签、且与原样本一致的假设。

引理 6.16 有限 DS 维的压缩构造 设 $d = d_{DS}(\mathcal{H}) < \infty$ 。存在通用常数 $C > 0$, 使得对每个整数 $n \geq 1$, 所有大小不超过 n 的 $\mathcal{H}$ 可实现样本均存在如下压缩表示: 从样本中选取一个允许重复、保留次序的带标签序列, 长度至多

$$r_n = \min\left\{n, \left\lceil C(d+1)^{3/2} \log^2(2n(d+1)) \right\rceil\right\},$$

³ N. Brukhim, D. Carmon, I. Dinur, S. Moran, A. Yehudayoff, *A Characterization of Multiclass Learnability* In Proceedings of the 63rd Annual Symposium on Foundations of Computer Science, 2022, pp. 943–955

并记录原样本的大小。对每个原样本大小，存在预先固定的重构映射，能够仅根据该压缩序列重构一个与原样本一致的假设。重构假设不要求属于 $\mathcal{H}$ 。

这是原论文定理 36 的一个放宽了常数和对数因子的表述。该构造的两项关键结果是：有限 DS 维允许用少量样本重构覆盖原样本的标签列表；给定列表后，有限 Natarajan 维允许再用少量样本重构一致的单标签预测。原论文引理 39 和 40 分别证明这两步。拼接两段压缩序列即可先重构列表、再重构分类器，且 $d_N \leq d$ 保证第二步也由 d 控制。取原论文中的参数 $t = \lceil \sqrt{d+1} \rceil$ ，所得长度不超过上述对数平方上界。若这个上界超过 n ，直接保存整个样本即可。列表构造所需的超图定向论证引用原论文，以下证明不将这一核心构造当作已在本章证明的结果。

有了压缩表示，可以沿用第 5 章的思路：可能的压缩序列数量有限，因此能够同时控制所有重构假设的期望风险。这里的计数取决于压缩长度，不取决于标签空间的大小。

定理 6.17 有限 DS 维的期望风险保证 在所需可测性条件成立的设定下，设 $d = d_{DS}(\mathcal{H}) < \infty$ ， $r = r_n < n$ ，并记

$$B_n(\delta) = \log \frac{2(n+1)(r+1)n^r}{\delta}.$$

存在允许非恰当输出的学习算法，使对任意 $\delta \in (0, 1)$ ，以下保证成立：

1. 对任意 $\mathcal{H}$ 可实现分布 $\mathcal{P}$ ，以至少 $1 - \delta$ 的概率，

$$R_{\mathcal{P}}(A^{\text{real}}(S)) \leq \frac{B_n(\delta)}{n - r}.$$

2. 对任意联合分布 $\mathcal{P}$ ，以至少 $1 - \delta$ 的概率，

$$\begin{aligned} R_{\mathcal{P}}(A^{\text{agn}}(S)) &\leq \inf_{h \in \mathcal{H}} R_{\mathcal{P}}(h) + \frac{r}{n} \\ &\quad + \sqrt{\frac{B_n(\delta)}{2(n-r)}} + \sqrt{\frac{\log(2/\delta)}{2n}}. \end{aligned}$$

证明（使用引理 6.16）. 长度至多 r 的有序压缩序列最多有 $(r+1)n^r$ 种索引选择。再计入原样本大小的 $n+1$ 种可能，重构方式至多有 $M = (n+1)(r+1)n^r$ 种。这里是在观察数据之前枚举索引，而不是预先枚举标签。

固定一种索引选择，并设它实际使用了 $q \leq r$ 个不同样本。给定这 q 个

样本的值后，重构假设已经确定；其余 $n - q$ 个样本仍独立同分布。若重构假设的期望风险超过 u ，它在这些剩余样本上全部正确的条件概率至多为 $(1 - u)^{n-q} \leq e^{-(n-r)u}$ 。可实现学习器选择一个与全部样本一致的重构假设，压缩引理保证这样的选择存在。对至多 M 种重构方式的失败概率求和，取 $u = B_n(\delta)/(n - r)$ ，便得到第一项结论。若 $u \geq 1$ ，结论直接由零一损失下的期望风险不超过 1 成立。

不可知学习器在这 M 种重构结果中选择经验风险最小者。固定一种重构方式，记其在未参与重构的样本上的经验风险为 $\hat{R}_{\text{rest}}$ 。由单侧 Hoeffding 不等式及上述条件独立性，以至少 $1 - \delta/2$ 的概率，所有重构结果同时满足

$$R_{\mathcal{P}}(h) \leq \hat{R}_{\text{rest}}(h) + \sqrt{\frac{\log(2M/\delta)}{2(n-r)}}.$$

从全部样本中去掉 q 个观测，经验风险最多增加 q/n ：将全部样本上的平均损失写成保留部分与删除部分的加权平均，即可得到 $\hat{R}_{\text{rest}}(h) \leq \hat{R}_S(h) + q/n$ 。于是上式可以用 $\hat{R}_S(h) + r/n$ 代替 $\hat{R}_{\text{rest}}(h)$ 。

对任意预先固定的比较假设 $g \in \mathcal{H}$ ，取样本中被 g 正确分类的全部观测。这部分样本可实现，压缩引理保证某个重构假设在这些观测上全部正确，因而其经验风险不超过 $\hat{R}_S(g)$ 。若这部分为空，该不等式对任意假设都成立。最小化重构结果的经验风险因此保证 $\hat{R}_S(A^{\text{agn}}(S)) \leq \hat{R}_S(g)$ 。再对固定 g 使用 Hoeffding 不等式，以至少 $1 - \delta/2$ 的概率有

$$\hat{R}_S(g) \leq R_{\mathcal{P}}(g) + \sqrt{\frac{\log(2/\delta)}{2n}}.$$

合并两项概率保证，再令固定比较假设的期望风险趋近于 $\inf_{g \in \mathcal{H}} R_{\mathcal{P}}(g)$ ，便得到第二项结论。 ■

对固定 d ，压缩长度 r_n 只按 $\log^2 n$ 增长，因此 $r_n/n \rightarrow 0$ 。上述两项期望风险上界都随样本量增加趋于相应的最优值。忽略关于 n, d 的对数因子，可实现期望风险为 $\tilde{O}((d^{3/2} + \log(1/\delta))/n)$ ，不可知超额期望风险为 $\tilde{O}(\sqrt{(d^{3/2} + \log(1/\delta))/n})$ 。这些是统计保证；压缩表示的存在没有保证找到它的程序可计算或运行时间为多项式。

将这一构造与前面的必要条件合起来，可以得到与二分类学习基本定理相对应的结论。二分类中由 VC 维统一刻画性质，在一般多分类中分成了图维和 DS 维两组条件；只有标签有限时，这两组条件的有限性才重新等价。

定理 6.18 多分类学习基本定理 对任意标签空间，在所需可测性条件成立且允许非恰当学习时，以下命题等价：

1. $d_{DS}(\mathcal{H}) < \infty$;
2. $\mathcal{H}$ 可实现 PAC 可学习;
3. $\mathcal{H}$ 不可知 PAC 可学习。

此外, $d_G(\mathcal{H}) < \infty$ 当且仅当零一损失满足分布无关的一致收敛; 这两个等价条件均蕴含上述三条, 但一般不存在反向蕴含。

证明 (使用有限 DS 维的学习器构造结果)。若 DS 维有限, 定理 6.17 分别给出可实现和不可知的分布无关期望风险保证, 选择足够大的样本量即可达到任意 ε, δ 。不可知 PAC 保证蕴含可实现 PAC 保证, 而无限 DS 维由前一定理排除可实现 PAC 学习。三个命题因而等价。图维与一致收敛的等价性见定理 6.9, 反向蕴含的失败由定理 6.11 给出。充分性中的学习器构造作为已引用的外部结果使用。 ■

因此, 一般多分类中应分别使用两条结论: 图维有限当且仅当零一损失一致收敛, DS 维有限当且仅当存在 PAC 学习器。前者推出后者, 后者不推出前者。若标签数有限, 则 d_N 、 d_{DS} 、 d_G 的有限性、一致收敛以及上述两种 PAC 可学习性全部等价; 二分类时三种维度均退化为 VC 维。这些结论由定理 6.14 和定理 6.4 得到。

定性刻画也不直接提供最优样本复杂度或高效实现, 不能把二分类样本量公式中的 VC 维简单替换为 DS 维。

6.4 可计算 PAC 学习

6.4.1 统计保证与程序实现

与第 5.7 节相同, 本节依次区分统计可学习、程序可计算、多项式时间可实现三个层次。变化的是标签从 0 和 1 扩展为 Y 中的元素, 训练与预测仍然必须停机, 期望风险的成功标准也不变。

沿用定义 5.24, 取 $X = \mathbb{N}$, 并为标签约定可计算编码和可判定的相等关系。多分类不可知 CPAC 学习器是一个对每份有限样本停机的程序, 输出一个对每个输入都能停机返回 Y 中标签的程序, 并满足

$$\mathbb{P}_{S \sim \mathcal{P}^n} \left\{ R_{\mathcal{P}}(A(S)) \leq \inf_{h \in \mathcal{H}} R_{\mathcal{P}}(h) + \varepsilon \right\} \geq 1 - \delta$$

对所有允许分布及所有足够大的 n 成立。要求输出属于 $\mathcal{H}$ 时称为恰当学习; 允许输出其他可计算假设时称为非恰当学习。样本量上界还要求可计算的 strong CPAC, 与前章使用同一约定, 不表示运行时间一定为多项式。

定理 6.19 多分类可计算 ERM 的充分条件 若 $\mathcal{H}$ 存在对所有有限样本都停机、输出假设可有效求值的恰当 ERM，并且 $d_G(\mathcal{H}) < \infty$ ，则 $\mathcal{H}$ 恰当地不可知 CPAC 可学习，且有可计算的样本量上界。有限标签时，可以将有限图维条件替换为有限 Natarajan 维。

证明. 定理 6.9 给出损失函数空间的有限 VC 维，因此有显式的一致收敛样本量上界。给定精度 $\varepsilon/2$ ，ERM 的两次偏差比较给出超额期望风险至多为 ε 。训练和预测的可计算性由题设保证。固定假设空间的有限维度上界可作为常数写入样本量程序。有限标签时，有限 Natarajan 维由定理 6.14 推出有限图维。 ■

这与前章可计算 ERM 的定理对应：二分类使用 VC 维，多分类使用损失空间的图维，有限标签下也可使用 Natarajan 维。只有统计维度有限而没有可计算 ERM 时，仍不能据此断言存在这样的程序。

6.4.2 可计算 Natarajan 维

有限 Natarajan 维保证：给定足够多的输入及每个输入处的两个标签，总有一种二元选择不能被实现。要利用这一条件编写程序，需要能够在有限时间内找出这样的选择。**可计算 Natarajan 维** (computable Natarajan dimension) 把这一有效见证要求写入维度定义。

定义 6.20 可计算 Natarajan 维 若存在总可计算程序 W ，对任意 $d+1$ 个互异输入 x_i 及标签对 (a_i, b_i) 、 $a_i \neq b_i$ ，都输出 $s \in \{0, 1\}^{d+1}$ ，使得

$$\nexists h \in \mathcal{H} \quad \forall i : h(x_i) = \begin{cases} a_i, & s_i = 0, \\ b_i, & s_i = 1, \end{cases}$$

则称 d 为可计算 Natarajan 维的一个上界。最小的这种非负整数记为 $c_N(\mathcal{H})$ ；不存在时记为 ∞ 。

普通 Natarajan 维只要求缺失的预测存在，可计算版本还要求一个统一程序找出它。所以 $d_N \leq c_N$ ；当标签只有两种时，这一概念回到前章的有效 VC 维。

证明的充分方向使用 Gourdeau 等的有效扩展引理：若 $c_N(\mathcal{H}) = d < \infty$ 且标签有限，可构造包含 $\mathcal{H}$ 的假设空间 $\mathcal{H}'$ ，使 $d_N(\mathcal{H}') \leq d+1$ ，并且有限输入上的全部可实现预测及其实现假设可有效求得⁴。以下明确区分这一外部构造与随后的统计推导。

⁴ P. Gourdeau, T. Lechner, R. Uerner, *On the Computability of Multiclass PAC Learning* In arXiv preprint arXiv:2502.06089, 2025

定理 6.21 有限标签的非恰当 CPAC 刻画 在上述有效编码模型中, 若 $2 \leq |Y| < \infty$, 则 $\mathcal{H}$ 非恰当地不可知 CPAC 可学习, 当且仅当 $c_N(\mathcal{H}) < \infty$ 。

证明 (充分性使用有效扩展引理)。必要性可通过可计算版本的没有免费的午餐论证得到。设存在 CPAC 学习器 A , 固定一个使精度 $1/16$ 、失败概率 $1/16$ 的 PAC 保证成立的样本量 n 。给定 $2n$ 个输入及每处两个不同标签, 枚举全部二元选择作为候选目标; 对每个候选目标, 枚举来自这 $2n$ 个输入的所有长度 n 的有序样本, 运行 A , 再计算输出在这 $2n$ 个输入上的错误比例。所有集合有限, 训练和预测都停机, 因而每个候选目标下的平均期望风险可计算。

随机二元目标的未见输入论证保证, 某个候选目标的平均期望风险至少为 $1/4$ 。程序找出这样一个目标并返回它的选择向量。该目标不可能属于 $\mathcal{H}$ 的限制, 否则 PAC 保证会使平均期望风险至多为 $1/16 + 1/16 < 1/4$ 。这就给出维度至多为 $2n - 1$ 的有效见证。这里 n 作为固定常数写入程序, 不要求从任意学习器描述中自动算出它。

充分性使用上述扩展 $\mathcal{H}'$ 。枚举有限样本上的可实现预测并选择错误最少的一种, 再输出其可计算实现, 得到一个可计算 ERM。由于标签有限且 $d_N(\mathcal{H}')$ 有限, 本章有限标签定理保证它不可知 PAC 学习 $\mathcal{H}'$ 。又因 $\mathcal{H} \subseteq \mathcal{H}'$, 有 $\inf_{h \in \mathcal{H}'} R_{\mathcal{P}}(h) \leq \inf_{h \in \mathcal{H}} R_{\mathcal{P}}(h)$, 故同一算法也满足相对于 $\mathcal{H}$ 的不可知保证, 但其输出未必属于 $\mathcal{H}$ 。 ■

此处学习器取确定性程序, 概率来自随机样本; 若采用额外随机化的计算模型, 必须同时约定随机位的使用方式, 不能直接假定可以枚举所有随机运行过程。

上述必要性证明没有使用标签集合有限, 因此无限标签下 CPAC 学习仍要求 $c_N < \infty$ 。充分性中的有效扩展则用到了有限标签的预测枚举, 不能直接推广。更强的是, 本章不可学习反例的构造并不因只检查标签对就消失: 一个有限的计算维度条件是否充分, 需要单独证明, 不能从统计定义的相似性推出。

有限 DS 维解决的是统计可学习性, 不自动提供伪立方体搜索、列表学习和单标签归约的可执行程序。因此不能把 DS 刻画直接改称为多分类 CPAC 定理。对于具体假设空间, 一条可验证的充分路线仍然是: 给出可计算 ERM, 并证明损失空间一致收敛; 有限标签和有限 Natarajan 维可以保证后一个条件, 任意标签下有限图维也可以。

6.4.3 高效学习与优化误差

可计算程序仍然可能运行很久。与前章一样，高效 PAC 学习还要控制样本量、训练时间、预测时间及输出表示长度。多分类需额外注意标签编码：标签数为 K 时，类别编号的长度约为 $\log K$ ；若输出标签本身是集合或其他结构，其描述长度也必须计入成本。

近似 ERM 的统计分析完全保留。若算法输出 $A(S) \in \mathcal{H}$ ，并满足

$$\hat{R}_S(A(S)) \leq \inf_{h \in \mathcal{H}} \hat{R}_S(h) + \alpha,$$

且所有假设的经验风险与期望风险之差不超过 η ，则

$$R_{\mathcal{P}}(A(S)) \leq \inf_{h \in \mathcal{H}} R_{\mathcal{P}}(h) + 2\eta + \alpha.$$

证明就是定理 5.28 的三步比较，不依赖标签有几个。其中 2η 来自抽样估计， α 来自优化误差。若能以多项式时间求得 $\alpha \leq \varepsilon/2$ 的解，并用多项式数量的样本使 $\eta \leq \varepsilon/4$ ，便得到高效不可知 PAC 学习的一条充分路线。

6.4.4 从枚举到有效算法

前章用布尔合取说明，逐个枚举假设很慢，并不意味着所有算法都很慢。多分类也可以用一个明确例子看出这一区别。令输入空间为 $X = \{1, \dots, p\}$ ，标签空间为 $Y = \{1, \dots, K\}$ ，并允许全部分类函数 $\mathcal{H} = Y^X$ 。共有 K^p 个假设，但经验风险最小化不必枚举它们。

对每个输入 x ，统计样本中它与各标签共同出现的次数 $N_{x,y} = |\{i : x_i = x, y_i = y\}|$ 。在 x 处选择出现次数最多的标签，平局时选择编号最小者；没有出现过的输入也按这一约定预测 1。不同输入处的选择相互独立，所以可以分别求解。

定理 6.22 有限输入上的多分类表学习 上述计数算法是 Y^X 上的恰当 ERM，需要 $O(n + pK)$ 次计数和比较操作，输出一张含 p 个标签的预测表。对任意 $\varepsilon, \delta \in (0, 1)$ ，若

$$n \geq \frac{2}{\varepsilon^2} \left(p \log K + \log \frac{2}{\delta} \right),$$

则以至少 $1 - \delta$ 的概率，其期望风险不超过 $\inf_{h \in \mathcal{H}} R_{\mathcal{P}}(h) + \varepsilon$ 。

证明. 任意假设 h 分对的样本总数为 $\sum_{x=1}^p N_{x,h(x)}$ 。每个 x 独立选取使 $N_{x,y}$ 最大的 y ，就使这个和最大，因此经验风险最小。初始化 pK 个计数器、扫描 n 个观测、逐行比较，得到所列操作数。又因 $|\mathcal{H}| = K^p$ ，有限假设空间的 Hoeffding 分析使 $\sup_h |R_{\mathcal{P}}(h) - \hat{R}_S(h)| \leq \varepsilon/2$ 的失败概率至多为

$2K^p e^{-n\epsilon^2/2}$ 。令其不超过 δ ，再使用 ERM 比较，即得结论。 ■

这里计算代价按 p 和 K 衡量；计数器的位数至多为 $O(\log(n+1))$ ，因此按比特计费也仍为这些参数的多项式。但若把 K 看成由一个很短程序描述的巨大标签空间，就不能把 $O(K)$ 误称为标签编码长度的多项式。输出预测表的长度为 $O(p \log K)$ ，也计入学习资源。

6.5 本章小结

多分类增加的不只是标签数量：同一输入可以改成多个不同标签，使二分类中由 VC 维统一刻画的性质在一般情形下分开。把标签编码成若干二元位虽然能构造分类器，却不能消除对子问题复杂度、错误累积与输出一致性的分析。有限标签下，Natarajan 维限制有限输入上的不同预测数目，使二分类中的计数、对称化与 ERM 比较仍然适用。因此，在本章的可测性条件下，有限 Natarajan 维、分布无关 PAC 可学习性与一致收敛三者等价。

标签空间无限时，需要把两个问题分开。图维刻画零一损失函数空间的 VC 维，决定能否用同一份样本同时准确评价全部假设。DS 维则刻画统计可学习性，允许学习算法只利用足够的预测信息，而不必准确评价整个假设空间。有限 Natarajan 维此时只保留必要性，不能独自保证学习成功。有限图维推出可学习性，反方向不成立；这正是二分类基本定理不能原样推广的原因。

这一区分也影响算法选择。经验风险同样达到最小值的学习器，可能具有不同的泛化表现，所以仅写出 ERM 目标不足以解释所有多分类学习现象。进一步要求训练与预测程序停机时，还要引入有效的组合条件；有限标签下的可计算 Natarajan 维提供了相应刻画，却不自动保证多项式运行时间。下一章将把评价对象扩展为一般损失，并从算法稳定性继续分析一致收敛之外的学习保证。

延伸阅读 Daniely 等关于多分类可学习性与 ERM 的研究，适合用来进一步理解“存在成功学习器”与“任意 ERM 都能成功”的区别。可重点对照文中的不同 ERM 表现与本章图维的作用，检查算法在多个经验最优假设之间怎样选择，会如何影响样本量⁵。。

Bruckhim 等给出了 DS 维对多分类可学习性的刻画。本章已经展开列表预测、压缩与单标签预测之间的统计推导；若要补全所引用的组合构造，应继续阅读原文中的伪立方体与列表学习分析。这些构造是深层的组合结果，不能由 Natarajan 维的有限标签证明直接替代⁶。。

计算方向可阅读 Gourdeau、Lechner 与 Uerner 的工作，重点核对标签编码、输出假设的求值要求以及恰当与非恰当学习的区别。它提供了与第 5.7 节有效 VC 维分析相对应的多分类视角⁷。。

⁵ A. Daniely, S. Sabato, S. Ben-David, S. Shalev-Shwartz, *Multiclass Learnability and the ERM Principle* In Journal of Machine Learning Research, 2015, vol. 16, no. 72, pp. 2377–2404

⁶ N. Bruckhim, D. Carmon, I. Dinur, S. Moran, A. Yehudayoff, *A Characterization of Multiclass Learnability* In Proceedings of the 63rd Annual Symposium on Foundations of Computer Science, 2022, pp. 943–955

⁷ P. Gourdeau, T. Lechner, R. Uerner, *On the Computability of Multiclass PAC Learning* In arXiv preprint arXiv:2502.06089, 2025

一般学习的可学习性

前两章用零一损失讨论分类：预测正确记 0，预测错误记 1。回归、聚类和降维需要更细的损失刻画，但仍然面临相同的困难：算法根据有限样本选择的结果，应当在新数据上也有较低的期望损失。分类中的选择结果是一个假设；聚类中的选择结果则是一组中心。本章将这些结果统称为决策，要回答的问题是：超出零一分类以后，哪些条件能让算法根据样本选出的决策在期望风险上仍接近最优？

前两章主要从假设空间出发。二分类的 VC 维约束不同预测的数目，多分类的图维则约束假设在带标签样本上能够形成的不同正误组合。在相应维度有限时，可以由此证明所有假设的经验风险以高概率同时接近各自的期望风险。一般学习问题还允许另一种情况：每份样本上都存在经验风险与期望风险相差很大的决策，但算法能够避开它们。这时，分析算法怎样根据样本选择决策，比要求整个决策空间满足一致收敛更有针对性。

算法稳定性 (algorithmic stability) 考察这种选择对单个观测的依赖：删除或替换一个观测以后，输出的损失会改变多少。适当的稳定性条件可以控制经验风险与期望风险之间的差别，再结合经验风险接近最优的条件，得到可学习性保证。为回答章首问题，本章先建立一致收敛和稳定性各自支持学习的条件，再讨论怎样通过正则化和随机梯度下降验证这些条件。凸性、参数约束和优化过程的性质各自承担不同作用，不能仅凭假设空间“具有某种结构”就断定学习成功。

7.1 一般学习问题

本章采用以下一般学习问题设定。单个观测记为 $z \in Z$ ，允许的数据分布组成 $\mathfrak{P}$ 。给定 $\mathcal{P} \in \mathfrak{P}$ ，训练样本 $S = (z_1, \dots, z_n)$ 独立取自 $\mathcal{P}$ 。 $\mathcal{W}$ 是比较决策空间， $\mathcal{W}_{\text{out}}$ 是算法实际允许输出的空间；损失 $\ell(w, z)$ 评价决策 w 在观测 z 上的表现。学习算法根据 S 及其内部随机数 U 输出 $A(S, U) \in \mathcal{W}_{\text{out}}$ ，并与 $\mathcal{W}$ 中期望风险最低的决策比较。相应的期望风险、经验风险和 PAC 量词见定义 4.2–4.4。

相对于前两章的分类特化，这里回到一般实值损失，分析重点由分类容

量转向损失函数空间、算法稳定性与经验优化误差。各定理再局部增加有界性、凸性、光滑性或矩条件。

7.1.1 观测、决策与损失

分类用“是否答错”评价一次预测，回归却需要区分错得多与错得少。例如，真实温度是 20，预测 18 与预测 10 都不完全正确，但平方损失分别为 4 和 100。聚类甚至没有预先给定的正确标签；它可以用数据点到最近聚类中心的距离评价一组中心。要讨论这些任务的学习能力，需要保留“用样本选择决策”的结构，同时允许损失采用不同的形式。

在这一设定中，观测 z 包含评价一次决策所需的信息；决策 w 可以是一个预测函数、一组聚类中心或一个投影矩阵。损失 $\ell(w, z)$ 为决策 w 在观测 z 上的表现赋予数值，数值越小表示在这一评价标准下表现越好。期望风险和经验风险分别按定义 4.2 与定义 4.3 计算，学习结果仍与 $\inf_{w \in \mathcal{W}} R_{\mathcal{P}}(w)$ 比较。

二分类取 $z = (x, y)$ 并用预测函数作为决策；回归也观察 (x, y) ，但可改用平方损失 $(w(x) - y)^2$ 。这些任务改变了损失与决策的具体形式，没有改变“用有限样本选择决策，再评价新观测”的共同结构。

聚类中，观测只包含输入 x ，决策则是一组中心 $w = (c_1, \dots, c_K)$ 。 K 均值的损失为 $\min_j \|x - c_j\|_2^2$ 。例如，一维数据点 $x = 2$ 面对中心 0 和 5 时，到两个中心的平方距离分别为 4 和 9，因而损失是 4。训练过程寻找平均距离较小的中心；期望风险考察新数据到这些中心的平均距离。PCA 也可作类似表述：决策是秩为 r 的正交投影 P ，损失 $\|x - Px\|_2^2$ 衡量投影后无法重构的部分。

这些任务都能写成期望风险最小化，但这一统一形式不保证它们都是凸问题，也不保证较低的期望风险必然恢复某个唯一的“真实聚类”或“真实子空间”。例如， K 均值对所有中心的联合优化一般并不凸。后面的定理只适用于满足其损失与决策空间条件的问题，不能仅凭形式相同就直接套用。

7.1.2 可学习性的目标

本章沿用定义 4.4 的不可知比较方式：不假定某个决策的期望风险为零，而是要求算法输出接近比较空间中的最低期望风险。一般学习问题没有必须恢复的标签函数；学习目标完全由观测分布、比较空间和损失函数共同确定。除非局部另行声明，本章取 $\mathcal{W}_{\text{out}} = \mathcal{W}$ ，即采用恰当输出。

可学习性仍是对整个学习问题的判断。例如，同一组预测函数在有界输入和平方损失下的学习保证，未必适用于允许任意重尾输入的情形。限制参数范围会改变决策空间，改用替代损失会改变评价目标，限制数据分布

则会缩小保证所覆盖的数据来源；讨论这些改变时，需要保留各自的条件。

在讨论维度刻画与必要条件时，本章明确采用有界损失；正则化与 SGD 的具体定理则分别列出凸性、Lipschitz 性和可积性等条件。不能将平方损失在有界区域内的结论直接推广到无约束、重尾的回归问题。

7.2 一致收敛

前两章的零一损失只有两个取值，平方损失则可以取连续多个数值。但我们要控制的对象没有改变：同一份样本上，每个决策的经验风险与对应的期望风险相差多少。这里应分析的是损失函数空间

$$\mathcal{F}_\ell = \{z \mapsto \ell(w, z) : w \in \mathcal{W}\},$$

而不是不经说明就把预测函数空间的维度代入。相同预测函数配上不同损失，得到的损失函数空间也可能具有不同的有界性和复杂度。

定义 7.1 一般学习问题的一致收敛 若对任意 $\eta, \delta \in (0, 1)$ ，存在整数 $n_{\text{uc}}(\eta, \delta)$ ，使任意允许分布 $\mathcal{P}$ 及任意 $n \geq n_{\text{uc}}(\eta, \delta)$ 均满足

$$\mathbb{P}_{S \sim \mathcal{P}^n} \left\{ \sup_{w \in \mathcal{W}} |\hat{R}_S(w) - R_{\mathcal{P}}(w)| \leq \eta \right\} \geq 1 - \delta,$$

则称损失函数空间满足分布无关的一致收敛。

样本量可以依赖决策空间、损失函数、精度和置信度，但不能随着未知的分布改变。这个定义仍然要求所有决策同时满足估计精度。为判断实值损失能否满足它，需要把前章的打散推广到带阈值的数值比较。

7.2.1 伪维与胖打散维

二分类的打散固定一组输入，要求假设能够实现全部 2^m 种 0、1 预测。多分类中，Natarajan 打散在每个输入处固定两个不同标签，再要求实现两者的全部选择组合。这两种定义都在检查同一件事：不同输入上的两种答案能否独立选择。

实值输出需要改变“两种答案”的含义。例如温度预测可能输出 19.8、20.1 或 23，要求它精确等于两个指定数值，会忽略与这些数值接近的预测。实数还具有大小关系，因此可以固定一个阈值，把两种答案改为“高于阈值”和“低于阈值”。这既保留了独立二元选择的结构，又不要求函数恰好输出预先指定的两个数值。

具体地，在第一天 x_1 指定 20 度，在第二天 x_2 指定 25 度。若函数空间能分别给出“都低于”“第一天高于、第二天低于”“第一天低于、第二天

高于”和“都高于”这四种预测，就能相对于这两个阈值打散两个输入。这称为伪打散（pseudo-shattering），能够伪打散的最大输入数目称为伪维（pseudo-dimension）。每个输入的阈值可以不同，但必须在检验全部组合之前固定，不能为不同组合重新选择阈值。

定义 7.2 伪打散 设 $\mathcal{F} \subseteq \mathbb{R}^X$ 。若有限集 $C = \{x_1, \dots, x_m\}$ 存在 $r_1, \dots, r_m \in \mathbb{R}$ ，使任意 $b \in \{0, 1\}^m$ 均对应某个 $f_b \in \mathcal{F}$ 满足

$$b_i = 1 \Rightarrow f_b(x_i) > r_i, \quad b_i = 0 \Rightarrow f_b(x_i) < r_i \quad (1 \leq i \leq m),$$

则称 C 被 $\mathcal{F}$ 伪打散。

定义 7.3 伪维 函数空间 $\mathcal{F}$ 的伪维定义为

$$\text{Pdim}(\mathcal{F}) = \sup\{|C| : C \subseteq X \text{ 为被 } \mathcal{F} \text{ 伪打散的有限集}\}.$$

当函数只取 0 和 1 时，只要一个输入能实现阈值两侧的选择，该阈值就必须位于 0 与 1 之间。反过来，取阈值 1/2 便把 0、1 预测转成低、高选择。因此，对二值函数空间有 $\text{Pdim}(\mathcal{F}) = \text{VC}(\mathcal{F})$ 。伪维是 VC 维向实值函数的推广。它与 Natarajan 维的区别在于，前者使用数值的大小关系，后者只要求两个类别标签不同；给类别随意编号后计算伪维，通常不能代替多分类维度。实值函数却有新的问题：以 20 为阈值，20.001 与 19.999 已经处于两侧，但在精度为 1 的风险估计中，这样小的差异不应与相差数度的预测同等看待。**胖打散**（fat-shattering）在阈值两侧各留出宽度 γ ，只计算能够跨过这段间隔的独立变化。

定义 7.4 胖打散 给定 $\gamma > 0$ 。若有限集 $C = \{x_1, \dots, x_m\}$ 存在实数 $r_1, \dots, r_m$ ，使任意 $b \in \{0, 1\}^m$ 均对应某个 $f_b \in \mathcal{F}$ 满足

$$b_i = 1 \Rightarrow f_b(x_i) \geq r_i + \gamma, \quad b_i = 0 \Rightarrow f_b(x_i) \leq r_i - \gamma, \quad (7.1)$$

则称 C 在尺度 γ 下被 $\mathcal{F}$ 胖打散。

定义 7.5 胖打散维 函数空间 $\mathcal{F}$ 在尺度 $\gamma > 0$ 下的**胖打散维**（fat-shattering dimension）定义为

$$\text{fat}_\gamma(\mathcal{F}) = \sup\{|C| : C \subseteq X \text{ 为在尺度 } \gamma \text{ 下被 } \mathcal{F} \text{ 胖打散的有限集}\}.$$

胖打散的有限输出几何已经放在 第一卷“数学准备”的“计数与计算”章。该例在两个输入上实现全部高低组合，并把系数范围与间隔 γ 画在同

一个输出平面；它同时显示 γ 超过可用幅度后维度为何降为 0。本章保留尺度维度与一致收敛的关系。

第一卷的分块常值例取系数范围 $[-1, 1]$ ： $\gamma = 0.5$ 时两个分块可以独立取 ± 0.5 ，所以两个输入被胖打散；若增大到 $\gamma = 1.2$ ，单个输入上的高低见证就至少相差 2.4，超过函数值允许的总宽度 2，胖打散维降为 0。这个例子说明，尺度越大，打散要求越严格；伪维只记录是否能分开，胖打散维还记录能分开多远。

尺度也能使无限伪维变得可控。令 $X = \mathbb{N}$ ，允许每个 $f(i)$ 独立取 0 或 $1/i$ 。任意有限输入集都能用阈值 $1/(2i)$ 伪打散，故伪维无限。但在尺度 γ 下，只有满足 $1/i \geq 2\gamma$ 的输入能实现两侧选择。因此

$$\text{fat}_\gamma(\mathcal{F}) = \left\lfloor \frac{1}{2\gamma} \right\rfloor < \infty.$$

越靠后的输入允许变化的幅度越小；固定一个正精度以后，需要区分的输入数目就有限了。

7.2.2 一致收敛与期望风险

当允许分布族包含观测空间上的全部概率分布时，对有界实值函数，所有正尺度下的胖打散维决定是否一致收敛。以下定理采用这一量词范围，并使用取值范围 $[0, 1]$ ；一般有界区间可先平移缩放。若一般学习问题只允许一个更小的分布族 $\mathfrak{P}$ ，有限胖打散维仍是充分条件，因为下面的结论同时覆盖更多分布；反向推论却可能失败，不能再称为相对于 $\mathfrak{P}$ 的一般刻画。损失无界时还需要尾部条件，不能只检查维度。这里及下文均假定涉及的上确界、算法和期望满足所需可测性条件。

定理 7.6 胖打散维与一致收敛 设 $(X, \mathcal{A})$ 为可测空间， $\mathcal{F}$ 为非空的 $[0, 1]$ 值可测函数空间。假定存在可数子空间 $\mathcal{F}_0 \subseteq \mathcal{F}$ ，使每个 $f \in \mathcal{F}$ 都是 $\mathcal{F}_0$ 中某个函数序列的逐点极限。则以下两个命题等价：

1. 对每个 $\gamma > 0$ ， $\text{fat}_\gamma(\mathcal{F}) < \infty$ 。
2. 对任意 $\eta, \delta \in (0, 1)$ ，存在整数 $n_0 = n_0(\mathcal{F}, \eta, \delta)$ ，使任意 X 上的概率分布 $\mathcal{P}$ 和任意 $n \geq n_0$ 均满足

$$\mathbb{P}_{(x_1, \dots, x_n) \sim \mathcal{P}^n} \left\{ \sup_{f \in \mathcal{F}} \left| \frac{1}{n} \sum_{i=1}^n f(x_i) - \mathbb{E}_{x \sim \mathcal{P}} f(x) \right| > \eta \right\} \leq \delta.$$

第二条明确要求同一个 n_0 适用于所有分布，而不是先固定分布再选择样本量。第一条要求每个正尺度的维度分别有限，并不要求它们具有共同的有限上界。定理中的可数逼近条件用于保证上确界的可测性；当 $\mathcal{F}$ 本

身可数时，直接取 $\mathcal{F}_0 = \mathcal{F}$ 即可。在有界条件下，逐点逼近也保证期望收敛，因此可以通过可数子空间处理第二条的概率事件。把 X 换成观测空间 Z ，并令 $\mathcal{F} = \mathcal{F}_\ell$ ，就得到损失函数空间的一致收敛结论；使用前须检查同样的有界性与可测性条件。

这是实值函数的尺度敏感维度定理，完整证明需要实值函数覆盖数的组合估计¹。其充分性沿用前章的副样本方法，但不再精确计数不同预测向量：在固定的有限样本上，将数值足够接近的损失向量放在同一组，用一个代表近似一组函数。有限胖打散维保证在给定精度下只需要受控数目的代表；再对代表应用集中不等式，并加入近似误差，就能同时控制全部函数。必要性则利用某个固定正尺度上任意大的打散集，构造经验平均与总体平均不能同时接近的分布。本章引用这一组合定理，不将上述思路作为覆盖数估计的完整证明。

有限伪维是一个方便的充分条件，因为胖打散必然也是伪打散；但前面的 0 或 $1/i$ 例子说明，伪维无限并不排除一致收敛。实际估计时，也可以使用第 5 章的 Rademacher 复杂度，直接根据样本上的函数取值给出期望风险上界。

¹ R. Colomboni, E. Esposito, A. Paudice, *An Improved Uniform Convergence Bound with Fat-Shattering Dimension* In arXiv preprint arXiv:2307.06644, 2023

定理 7.7 一致收敛推出一般学习保证 若一份样本及算法输出满足

$$\sup_w |\hat{R}_S(w) - R_{\mathcal{P}}(w)| \leq \eta, \quad \hat{R}_S(A(S)) \leq \inf_w \hat{R}_S(w) + \alpha,$$

则

$$R_{\mathcal{P}}(A(S)) \leq \inf_w R_{\mathcal{P}}(w) + 2\eta + \alpha.$$

若损失函数空间满足分布无关的一致收敛，且算法对每份样本都满足上述经验优化条件，其中 $\alpha = \alpha_n$ 以不依赖数据分布的速率趋于零，则该算法分布无关 PAC 学习此问题。

证明. 对任意固定比较决策 w ，依次比较期望风险、经验风险和经验最优值，得到

$$\begin{aligned} R_{\mathcal{P}}(A(S)) &\leq \hat{R}_S(A(S)) + \eta \\ &\leq \hat{R}_S(w) + \alpha + \eta \\ &\leq R_{\mathcal{P}}(w) + \alpha + 2\eta. \end{aligned}$$

对 w 取下确界即可。取 $\eta \leq \varepsilon/4$ 、 $\alpha \leq \varepsilon/2$ ，并让一致收敛事件的概率至少为 $1 - \delta$ ，便得到 PAC 保证。 ■

这个推导不依赖凸性，只使用一致收敛和经验风险接近最优这两个条件。与多分类的讨论一样，得到充分条件以后，还需判断一致收敛是否也

是可学习性的必要条件。

7.2.3 一致收敛不是必要条件

前一定理给出了一致收敛的充分作用，但它可能同时约束了算法根本不会选择的决策。以下一般学习问题把这种差别直接展示出来。令观测空间为 $Z = [0, 1]$ ，决策空间包含一个特殊决策 w_0 以及所有有限集合 $C \subset [0, 1]$ ，并令

$$\ell(w_0, z) = 0, \quad \ell(C, z) = \mathbb{I}\{z \notin C\}.$$

w_0 在任何观测上都不产生损失；有限集合决策只在观测属于该集合时不产生损失。

定理 7.8 可学习性不推出一致收敛 上述一般学习问题 PAC 可学习，但损失函数空间不满足分布无关的一致收敛。

证明. 始终输出 w_0 的算法在每个分布下都具有零期望风险，因此达到最优。另一方面，令 $\mathcal{P}$ 为 $[0, 1]$ 上的均匀分布。对任何有限样本 S ，记其出现过的观测构成的集合为 C_S ，则

$$\hat{R}_S(C_S) = 0, \quad R_{\mathcal{P}}(C_S) = 1.$$

前者因为每个样本点都属于 C_S ，后者因为有限点集在连续均匀分布下的概率为零。因此全体决策的最大经验风险与期望风险之差恒为 1，不可能一致收敛。 ■

在这个固定的决策空间中，可以比较两个算法：一个始终输出 w_0 ，另一个输出样本点组成的集合 C_S 。两者的经验风险都为零，因而都属于 ERM；但在均匀分布下，前者的期望风险为零，后者的期望风险为 1。差别来自算法怎样在多个经验最优决策之间作出选择。要保证前一个算法能够学习，并不需要从决策空间中删除所有 C_S ，只需要算法始终选择已有的最优决策 w_0 。

这个人为构造的例子用于区分可学习性与一致收敛，不与二分类基本定理冲突。此处损失已经固定，允许分布作用于观测 z ；二分类的分布无关保证则允许任意输入与标签的联合分布。既然一般学习问题中的成功可能依赖具体的选择方式，接下来就需要考察算法本身的性质。

7.3 算法稳定性与可学习性

上一节的两个 ERM 使用同一个决策空间，却有不同期望风险。这说明，只描述哪些决策可以被选择，还不足以解释一个具体算法的泛化行为。算

法稳定性进一步考察样本与输出之间的关系：删除或替换一个观测后，最终输出的损失会改变多少。它是算法相对于给定损失函数的性质；即使决策空间不变，改变优化方法，或者改变多个决策具有相同经验风险时的选择方式，也可能改变稳定性。

留一法删除一个观测；替换分析则保持样本量不变，既可以要求所有相邻样本上的损失变化都小，也可以只控制随机抽样下的平均变化。若算法输出的是参数，还可以先研究参数的变化，再借助损失函数的性质得到损失变化的上界。信息论还允许直接研究输出与样本之间的依赖。这些稳定性条件都需要与经验最优性结合，才能推出可学习性；本节的基本论证不要求损失凸。

这里需要区分两种误差。**期望泛化差**对训练样本取期望，衡量经验风险平均低估了多少期望风险，其表达式为

$$\mathbb{E}_S[R_{\mathcal{P}}(A(S)) - \hat{R}_S(A(S))].$$

超额期望风险衡量输出距离决策空间中的最优表现还有多远，其表达式为

$$R_{\mathcal{P}}(A(S)) - \inf_{w \in \mathcal{W}} R_{\mathcal{P}}(w).$$

前者的绝对值小，只说明经验评价与总体评价在平均意义下接近；后者小，才说明算法学到了好的决策。下面对每一种稳定性分别说明它如何联系这两个量，以及在什么条件下得到 PAC 保证。

定理 7.9 期望泛化差与经验最优性 设 $A(S, U) \in \mathcal{W}$ ，相关损失可积。若对所有允许分布均有

$$\mathbb{E}_{S,U}[R_{\mathcal{P}}(A(S, U)) - \hat{R}_S(A(S, U))] \leq g_n,$$

以及

$$\mathbb{E}_{S,U}\left[\hat{R}_S(A(S, U)) - \inf_{w \in \mathcal{W}} \hat{R}_S(w)\right] \leq \rho_n,$$

其中 g_n, ρ_n 为不依赖具体分布的非负数，则

$$\mathbb{E}_{S,U} R_{\mathcal{P}}(A(S, U)) - \inf_{w \in \mathcal{W}} R_{\mathcal{P}}(w) \leq g_n + \rho_n. \quad (7.2)$$

若 $g_n + \rho_n \rightarrow 0$ ，则算法分布无关 PAC 学习此问题；条件 $g_n + \rho_n \leq \varepsilon \delta$ 足以使超额期望风险超过 ε 的概率不超过 δ 。

证明. 固定任意不依赖样本的 $w \in \mathcal{W}$, 将期望风险差分解为

$$\begin{aligned}\mathbb{E}[R_{\mathcal{P}}(A(S, U)) - R_{\mathcal{P}}(w)] &= \mathbb{E}[R_{\mathcal{P}}(A(S, U)) - \hat{R}_S(A(S, U))] \\ &\quad + \mathbb{E}[\hat{R}_S(A(S, U)) - \hat{R}_S(w)] \\ &\quad + \mathbb{E}[\hat{R}_S(w) - R_{\mathcal{P}}(w)].\end{aligned}$$

三项分别不超过 g_n 、 ρ_n 和 0, 其中第三项恰为零。对 w 取下确界得到式 (7.2)。由于输出属于比较空间, 超额期望风险非负; 对它应用 Markov 不等式即可得到概率结论。■

以下定义需要从扰动单位、直接比较对象、平均方式和保证类型上区分。平均留一法删除一个观测, 使样本量从 n 变为 $n-1$, 再比较删除前后在被删观测上的损失绝对差。它对样本和删除位置取平均, 可以联系 n 项经验风险与 $n-1$ 项训练的期望风险。均匀稳定性保持样本量不变, 替换一个观测, 并要求两次输出在任意测试观测上的损失差都受到控制; 在有界损失下, 这种最坏情形条件还能支持高概率界。平均稳定性也替换一个观测, 但只对样本、新观测、替换位置和算法随机性取平均, 由此精确联系期望泛化差。

参数稳定性先比较共享算法随机数时的输出参数距离, 再借助损失的 Lipschitz 性质或自界条件, 把参数变化转成损失与期望风险保证。互信息稳定性不显式构造相邻样本, 而是量化输出与整份训练样本的统计依赖。条件互信息稳定性则先给出每个位置的两个备选观测, 再衡量已知这些备选观测后, 算法输出揭示了多少选择信息。两种信息稳定性都可以控制期望泛化差, 后者结合经验最优性还能够用于可学习性的存在性刻画。比较这些稳定性时, 必须分别保留各自的量词、常数和附加条件。

7.3.1 留一法稳定性

经验风险在训练时已经用过的观测上评价算法, 期望风险则面对独立的新观测。连接两者的一种办法是暂时删去一个观测, 用剩余样本训练, 再在被删去的观测上评价。记 A_n 为使用 n 个观测的学习算法, $S^{\setminus i}$ 为从 S 中删除第 i 项后得到的样本。这样, z_i 独立于 $S^{\setminus i}$, 对于 $A_{n-1}(S^{\setminus i})$ 就是新观测。

定义 7.10 留一法风险估计 对确定性学习算法序列 $(A_n)_{n \geq 1}$, $n \geq 2$ 时的留一法风险估计定义为

$$\hat{R}_S^{\text{loo}}(A) = \frac{1}{n} \sum_{i=1}^n \ell(A_{n-1}(S^{\setminus i}), z_i).$$

留一法需要在不同的删减样本上重新训练。它与经验风险的区别在于: 评价 z_i 时, 前者使用没见过 z_i 的决策, 后者使用见过全部样本的决策。留

一法稳定性 (leave-one-out stability) 衡量这两个决策在被删观测上的损失相差多少。

定义 7.11 平均留一法稳定性 若对每个允许分布 $\mathcal{P}$ 都有

$$\frac{1}{n} \sum_{i=1}^n \mathbb{E}_{S \sim \mathcal{P}^n} |\ell(A_n(S), z_i) - \ell(A_{n-1}(S^{[i]}), z_i)| \leq \beta_n^{\text{loo}},$$

则称算法序列具有速率 β_n^{loo} 的分布无关平均留一法稳定性。

这里平均的是样本和被删除的位置, 只评价被删观测; 并未要求每份样本、每个测试点都满足同一个损失差上界。文献中还有在概率或二阶矩意义下的留一法稳定性, 本节明确采用上述平均绝对差版本²。

例如, 对 $z_i \in [0, 1]$ 输出样本均值, 并使用绝对损失。删除第 i 项后的均值为 $\bar{z}_{-i}$, 有 $\bar{z} - \bar{z}_{-i} = (z_i - \bar{z}_{-i})/n$, 故两次输出的距离不超过 $1/n$ 。绝对损失的三角不等式随即给出 $\beta_n^{\text{loo}} \leq 1/n$ 。这个例子检验的是稳定性, 并不声称样本均值最小化绝对损失。

² O. Bousquet, A. Elisseeff, *Stability and Generalization* In Journal of Machine Learning Research, 2002, vol. 2, pp. 499–526

定理 7.12 留一法稳定性与期望风险 设相关损失可积, 算法序列具有速率 β_n^{loo} 的平均留一法稳定性。对 $S \sim \mathcal{P}^n$ 及 $T \sim \mathcal{P}^{n-1}$, 有

$$|\mathbb{E}_T R_{\mathcal{P}}(A_{n-1}(T)) - \mathbb{E}_S \hat{R}_S(A_n(S))| \leq \beta_n^{\text{loo}}.$$

证明. 被删去的 z_i 独立于 $S^{[i]}$, 所以

$$\mathbb{E}_S \hat{R}_S^{\text{loo}}(A) = \mathbb{E}_{T \sim \mathcal{P}^{n-1}} R_{\mathcal{P}}(A_{n-1}(T)).$$

两侧减去 $\mathbb{E}_S \hat{R}_S(A_n(S))$, 再对左侧取绝对值。三角不等式将它控制为各项删除前后损失绝对差的平均, 至多为 β_n^{loo} 。 ■

这条结论把 n 个观测上的经验风险联系到使用 $n-1$ 个观测训练后的期望风险。样本量相差 1, 是因为独立评价需要留出一个观测; 它不是同一个 A_n 的期望泛化差上界。即使这个差很小, 经验风险本身仍可能很大。要说明算法能够学习, 还须保证它在样本上的表现接近决策空间中可达到的最优表现。

定理 7.13 留一法稳定性与可学习性 设 $A_n(S) \in \mathcal{W}$, 相关损失可积, 算法序列具有分布无关平均留一法稳定性 β_n^{loo} , 且对所有允许分布都有

$$\mathbb{E}_S \left[\hat{R}_S(A_n(S)) - \inf_{w \in \mathcal{W}} \hat{R}_S(w) \right] \leq \rho_n.$$

则对 $T \sim \mathcal{P}^{n-1}$,

$$\mathbb{E}_T R_{\mathcal{P}}(A_{n-1}(T)) - \inf_{w \in \mathcal{W}} R_{\mathcal{P}}(w) \leq \beta_n^{\text{loo}} + \rho_n.$$

若 $\beta_n^{\text{loo}} \rightarrow 0$ 且 $\rho_n \rightarrow 0$, 则该算法序列 PAC 学习此问题。使用 m 个观测达到精度 ε 与置信度 $1 - \delta$ 的一个充分条件是 $\beta_{m+1}^{\text{loo}} + \rho_{m+1} \leq \varepsilon \delta$ 。

证明. 对任意不依赖样本的 $w \in \mathcal{W}$, 经验优化误差条件给出

$$\mathbb{E}_S \hat{R}_S(A_n(S)) \leq \mathbb{E}_S \hat{R}_S(w) + \rho_n = R_{\mathcal{P}}(w) + \rho_n.$$

代入定理 7.12, 再对 w 取下确界, 得到超额期望风险的期望上界。对非负的超额期望风险应用 Markov 不等式, 失败概率至多为 $(\beta_n^{\text{loo}} + \rho_n)/\varepsilon$ 。令 $m = n - 1$ 即得所述样本量条件。 ■

留一法稳定性控制独立评价与经验评价之间的差, ρ_n 控制经验拟合是否足够好。两者以不依赖分布的速率趋于零, 共同给出可学习性的充分条件。后面的必要性刻画采用保持样本量不变的替换型稳定性, 不能直接套用到这里的删除型定义上。

7.3.2 均匀稳定性

留一法在被删除的观测处作平均比较。若希望对每份样本和每个测试观测都控制损失变化, 就需要均匀稳定性 (uniform stability)。下面采用替换一个观测的定义。

称 S 和 $S^{(i)}$ 相邻, 如果它们只有第 i 个观测不同。稳定性比较在两个相邻样本上运行同一算法所得的预测损失。

图 7.1 展示了稳定性所做的思想实验。我们不比较两批完全独立的样本, 而只替换一个观测, 并让算法的其他设置保持不变。如果这一个局部改动就能使任意测试点上的损失大幅变化, 训练结果就会对某个样本的偶然出现敏感; 反之, 若每个单点影响都很小, 训练样本中的自我影响便能被逐项换成独立样本, 从而导出泛化结论。

均匀稳定性要求所有相邻样本、所有测试观测上的损失变化都满足同一个上界。

定义 7.14 均匀稳定性 若对任意相邻 S, S' 和任意 $z \in Z$ 都有

$$|\ell(A(S), z) - \ell(A(S'), z)| \leq \beta_n, \quad (7.3)$$

则称算法 A 具有 β_n 均匀稳定性。




图 7.1 算法稳定性的相邻样本实验。两批样本只替换一个观测，同一算法分别输出 $w = A(S)$ 与 $w' = A(S')$ 。两支在同一测试点 z 上计算损失，再比较绝对差；均匀稳定性要求所有这样的损失差都不超过 β_n 。图中的比较对象是损失，不是参数距离。

这里 A 表示固定样本量 n 时的算法 A_n 。均匀稳定性与一致收敛约束的对象不同：前者比较相邻样本产生的两个输出，后者同时比较整个决策空间的经验风险与期望风险。

删除与替换也不能直接互换。若一个算法只按样本量奇偶输出两个不同常量，则同一 n 下替换任何观测都不改变输出，但删除一个观测会使输出跳变。因此替换型均匀稳定性本身不保证留一法稳定性。若另有对所有测试观测成立的均匀删除稳定性，则可从两份相邻样本中各删去被替换的位置，得到同一份 $n-1$ 项样本，再用三角不等式得到至多两倍的替换稳定性上界。

例如，观测 $z_i \in [0, 1]$ ，算法输出样本均值 $A(S) = \bar{z}$ ，用绝对误差 $\ell(w, z) = |w - z|$ 评价输出。替换一条观测最多使均值改变 $1/n$ 。对同一个测试观测 z ，三角不等式给出

$$||\bar{z} - z| - |\bar{z}' - z|| \leq |\bar{z} - \bar{z}'| \leq \frac{1}{n}.$$

因此这个算法具有 $1/n$ 均匀稳定性。这里仅用均值说明如何检查稳定性，并没有声称均值最小化绝对误差；经验拟合好坏还需要另行分析。

定理 7.15 均匀稳定性与期望风险 设 $S \sim \mathcal{P}^n$ ，相关损失可积。若 A 具有 β_n 均匀稳定性，则

$$|\mathbb{E}_S [R_{\mathcal{P}}(A(S)) - \hat{R}_S(A(S))]| \leq \beta_n. \quad (7.4)$$

证明. 取与 S 独立的 $z'_i \sim \mathcal{P}$ ，令 $S^{(i)}$ 把 z_i 替换为 z'_i 。交换 z_i 与 z'_i 不改变全部独立观测的联合分布，因而 (S, z_i) 与 $(S^{(i)}, z'_i)$ 同分布。这使经验风险

项可写成 $\mathbb{E}\ell(A(S^{(i)}), z'_i)$, 而期望风险项为 $\mathbb{E}\ell(A(S), z'_i)$ 。因此

$$\begin{aligned} & \mathbb{E}_S[R_{\mathcal{P}}(A(S)) - \hat{R}_S(A(S))] \\ &= \frac{1}{n} \sum_i \mathbb{E}[\ell(A(S), z'_i) - \ell(A(S^{(i)}), z'_i)] \leq \beta_n. \end{aligned}$$

交换 S 与 $S^{(i)}$ 得到反向界。

■

替换前, z'_i 是独立测试点; 替换后, 它是 $S^{(i)}$ 中的训练点。可交换性保证后一个损失的期望正好等于原来的训练损失, 稳定性则控制两个算法在同一个 z'_i 上的差异。证明不需要对整个决策空间取上确界, 这正是它与一致收敛论证的区别。这里假定涉及的损失可积, 以使期望与求和都有定义。

这里控制的是先取平均、再取绝对值的泛化差, 不是泛化差绝对值的平均, 也不是每份样本上的保证。对随机算法 $A(S, U)$, 本章使用内部随机性平均后的均匀稳定性:

$$\sup_{S, S' \text{ 相邻}, z \in Z} |\mathbb{E}_U \ell(A(S, U), z) - \mathbb{E}_U \ell(A(S', U), z)| \leq \beta_n.$$

其中 U 独立于样本。对前面的替换样本证明再取 U 的期望, 便得到对 S, U 共同平均的泛化差上界。它不意味着每次随机运行都满足相同的损失差界。留一法也可用相同约定: 先对损失取内部随机性的期望, 再计算删除前后的平均绝对差。留一法风险恒等式及其学习保证仍然成立。

均匀稳定性与可学习性的联系还需要经验优化误差。如果算法输出属于 $\mathcal{W}$, 且期望经验优化误差不超过 ρ_n , 定理 7.9 取 $g_n = \beta_n$ 便给出期望超额风险上界 $\beta_n + \rho_n$ 及相应 PAC 保证。因此, 如果 $\beta_n \rightarrow 0$ 而算法的经验风险始终远高于最优值, 仍不能保证学到好的决策; 这项充分条件也没有要求一个学习问题中的每个成功算法都必须均匀稳定。

上面的 PAC 保证还依赖经验优化误差。如果只希望用经验风险给期望风险加上一个高概率成立的上界, 可以继续利用均匀稳定性控制泛化差的波动。在有界损失下, 替换一个观测对整个泛化差的影响也有统一上界, 从而能应用集中不等式。为区分算法随机性与样本随机性, 下面先讨论确定性算法。

定理 7.16 均匀稳定性的高概率泛化界 设 $0 \leq \ell \leq 1$, 确定性算法 A 具有替换型 β_n 均匀稳定性。则任意 $\delta \in (0, 1)$ 下, 以至少 $1 - \delta$ 的

样本概率, 有

$$|R_p(A(S)) - \hat{R}_S(A(S))| \leq \beta_n + (2n\beta_n + 1) \sqrt{\frac{\log(2/\delta)}{2n}}.$$

证明. 记 $g(S) = R_p(A(S)) - \hat{R}_S(A(S))$ 。替换一个观测后, 期望风险变化至多 β_n ; 经验风险的 $n-1$ 个共同观测各变化至多 β_n , 被替换项变化至多 1。因此 $|g(S) - g(S')| \leq 2\beta_n + 1/n$ 。对 n 个独立观测应用有界差分不等式, $g(S)$ 偏离其期望的绝对值以至少 $1-\delta$ 的概率不超过 $(2n\beta_n + 1)\sqrt{\log(2/\delta)/(2n)}$ 。再使用 $|\mathbb{E}g(S)| \leq \beta_n$ 即得结论。■

这条直接推导的界在 $\beta_n = O(1/n)$ 时已有用, 但当稳定性下降较慢时, $n\beta_n$ 因子会显得过大。更精细的集中分析将其改进为

$$|R_p(A(S)) - \hat{R}_S(A(S))| \leq C \left(\beta_n \log(2n) \log \frac{2}{\delta} + \sqrt{\frac{\log(2/\delta)}{n}} \right)$$

的高概率界, 其中 C 是通用常数。此处引用 Bousquet、Klochkov 与 Zhivotovskiy 的结果, 不展开其高阶矩证明³。对随机算法, 上述集中结论可应用于内部随机性平均后的损失; 要控制单次随机输出, 还需另行控制算法随机性, 不能直接照搬。

稳定性的充分条件回答了怎样验证一个算法; 还可以进一步讨论: 一个问题只要可学习, 是否总能找到均匀稳定的算法。为此, 需要把“经验风险接近最优”写成对每份样本成立的条件。

定义 7.17 始终渐近经验风险最小化 设随机算法 $A(S, U)$ 的输出属于 $\mathcal{W}$, U 独立于样本。若存在 $\rho_n \rightarrow 0$, 使任意 $S \in \mathcal{Z}^n$ 均满足

$$\mathbb{E}_U \hat{R}_S(A(S, U)) - \inf_{w \in \mathcal{W}} \hat{R}_S(w) \leq \rho_n,$$

则称 A 为始终渐近经验风险最小化算法 (always AERM)。

“始终”要求每份样本都满足同一个经验优化误差上界, 只对算法内部随机性取平均。若只要求对每个允许分布下的样本取期望后满足同一速率, 则称分布无关 AERM。下面的基本定理采用更强的始终 AERM 条件, 给出均匀稳定性与可学习性的存在性关系⁴。

定理 7.18 一般学习基本定理: 均匀稳定性与可学习性 设 $0 \leq \ell(w, z) \leq 1$, 允许 $\mathcal{Z}$ 上的所有分布以及输出属于 $\mathcal{W}$ 的随机算法, 并假定所需可测性条件成立。则以下两个命题等价:

³ O. Bousquet, Y. Klochkov, N. Zhivotovskiy, *Sharper Bounds for Uniformly Stable Algorithms* In Proceedings of the Thirty Third Conference on Learning Theory, 2020, pp. 610–626

⁴ S. Shalev-Shwartz, O. Shamir, N. Srebro, K. Sridharan, *Learnability, Stability and Uniform Convergence* In Journal of Machine Learning Research, 2010, vol. 11, no. 90, pp. 2635–2670

1. 该问题分布无关 PAC 可学习;
2. 存在始终 AERM 算法, 具有对内部随机性平均后的替换型均匀稳定性, 且 $\rho_n \rightarrow 0$ 、 $\beta_n \rightarrow 0$ 。

证明. 命题 2 蕴含命题 1: 定理 7.15 给出 $g_n = \beta_n$ 的期望泛化差上界, 再由定理 7.9 得到 PAC 保证。

为证明命题 1 蕴含命题 2, 设已有学习算法 B 。有界损失下, PAC 保证蕴含某个分布无关的平均超额期望风险上界 $a_k \rightarrow 0$: 把超额期望风险按成功和失败事件分开, 其期望至多为 $\varepsilon + \delta$, 再令二者随样本量趋于零即可。

构造一个新算法。给定 S , 从其 n 个位置中独立、有放回地抽取 $k = \lfloor \sqrt{n} \rfloor$ 个位置, 把抽出的序列 T 交给 B , 输出 $B(T)$ 。固定 S 后, T 是从经验分布 $\mathcal{P}_S = n^{-1} \sum_i \delta_{z_i}$ 抽取的独立样本。这里 δ_{z_i} 表示在 z_i 处取值的点质量分布, 且 $R_{\mathcal{P}_S}(w) = \hat{R}_S(w)$ 。将 B 的学习保证应用于 $\mathcal{P}_S$, 得到

$$\mathbb{E}_U \hat{R}_S(B(T)) - \inf_w \hat{R}_S(w) \leq a_k.$$

这对每份 S 都成立, 因此新算法始终 AERM, $\rho_n = a_k \rightarrow 0$ 。

再在两个相邻样本上使用相同抽样索引及 B 的相同内部随机数。如果 k 次抽样都没有选中被替换的位置, 两次输入 T 完全相同, 输出也相同。选中该位置的概率至多为 k/n , 而损失差至多为 1, 所以 $\beta_n \leq k/n \rightarrow 0$ 。新算法同时满足两项条件, 必要性得证。 ■

必要性通过重新构造算法成立, 不能据此断言原来的每个成功算法都均匀稳定。证明中的子样本算法用于建立存在性, 并不保证最佳样本效率或计算效率。

7.3.3 平均稳定性

均匀稳定性要求一个损失差上界适用于所有相邻样本和所有测试观测。但在定理 7.15 的期望泛化差证明中, 最终使用的是随机样本下的平均损失差。如果某些变化较大的样本很少出现, 逐份样本取最坏情形就可能高估它们对期望泛化差的影响。因此, 我们可以直接研究随机替换一个观测后, 损失平均增加多少。

仍令 $S = (z_1, \dots, z_n) \sim \mathcal{P}^n$, 取独立新观测 $z'_i \sim \mathcal{P}$, 用它替换 z_i 得到 $S^{(i)}$ 。这次把评价点固定为被替换出去的 z_i : $A(S)$ 训练时使用了它, $A(S^{(i)})$ 训练时没有使用它。比较两者在 z_i 上的损失, 就能衡量使用这个观测训练后, 算法在该观测上获得了多少优势。对样本、新观测和替换位置取平均, 得

到**平均稳定性** (on-average stability)。下面采用平均替换稳定性的一侧定义, 与《Understanding Machine Learning》第13章中的约定一致⁵。

定义 7.19 平均稳定性 设 U 为独立于所有观测的算法内部随机数, 且相关损失可积。定义

$$\gamma_n(A, \mathcal{P}) = \frac{1}{n} \sum_{i=1}^n \mathbb{E}_{S, z'_i, U} [\ell(A(S^{(i)}, U), z_i) - \ell(A(S, U), z_i)]. \quad (7.5)$$

给定 $\bar{\beta}_n(\mathcal{P}) \geq 0$, 若 $\gamma_n(A, \mathcal{P}) \leq \bar{\beta}_n(\mathcal{P})$, 则称算法在分布 $\mathcal{P}$ 下具有速率 $\bar{\beta}_n(\mathcal{P})$ 的平均稳定性。若对所有允许分布均有 $\gamma_n(A, \mathcal{P}) \leq \bar{\beta}_n$, 且 $\bar{\beta}_n$ 不依赖 $\mathcal{P}$, 则称算法具有速率 $\bar{\beta}_n$ 的分布无关平均稳定性。

确定性算法可以省略 U 。这里平均的是带正负号的损失差, 允许不同样本上的增减相互抵消; 定义只限制其平均增加量, 没有要求每一次替换都几乎不影响损失。若改为对每个损失差取绝对值后再平均, 就得到更强的条件。均匀稳定性可以推出本定义中的平均稳定性, 反向推论一般不成立。它与平均留一法稳定性的区别也不只是名称: 这里两次训练都使用 n 个观测, 前面的留一法则比较 n 个与 $n-1$ 个观测的训练结果。

定理 7.20 平均稳定性与期望风险 在定义 7.19 的条件下,

$$\mathbb{E}_{S, U} [R_{\mathcal{P}}(A(S, U)) - \hat{R}_S(A(S, U))] = \gamma_n(A, \mathcal{P}). \quad (7.6)$$

因此, 速率为 $\bar{\beta}_n(\mathcal{P})$ 的平均稳定性保证

$$\mathbb{E}_{S, U} R_{\mathcal{P}}(A(S, U)) \leq \mathbb{E}_{S, U} \hat{R}_S(A(S, U)) + \bar{\beta}_n(\mathcal{P}).$$

证明. 替换后, $S^{(i)}$ 仍由 n 个独立同分布的观测组成, 而且独立于被替换出去的 z_i 。在给定 $S^{(i)}$ 和 U 时, 对 z_i 取期望得到

$$\mathbb{E}_{z_i} \ell(A(S^{(i)}, U), z_i) = R_{\mathcal{P}}(A(S^{(i)}, U)).$$

再利用 $S^{(i)}$ 与 S 同分布, 得到 $\mathbb{E} \ell(A(S^{(i)}, U), z_i) = \mathbb{E}_{S, U} R_{\mathcal{P}}(A(S, U))$ 。另一方面, n 个原观测上的损失平均恰好是经验风险, 故

$$\frac{1}{n} \sum_{i=1}^n \mathbb{E}_{S, U} \ell(A(S, U), z_i) = \mathbb{E}_{S, U} \hat{R}_S(A(S, U)).$$

两式相减即得恒等式, 再代入平均稳定性上界, 得到期望风险的上界。■

这个恒等式说明, 平均替换损失差恰好等于经验风险对期望风险的平均低估量。它提供的是对多次抽样和训练取平均后的关系。对于某一次训

⁵ S. Shalev-Shwartz, S. Ben-David, *Understanding Machine Learning: From Theory to Algorithms*, Cambridge University Press, 2014, 1st ed.

练结果，期望风险与经验风险之差仍可能超过这个上界；仅有这一关系，也不能推出泛化差绝对值的平均很小。对于某个固定分布得到的稳定性速率，还需要进一步取得不依赖分布的上界，才能用于分布无关的可学习性结论。

平均稳定性给出了期望泛化差上界。与均匀稳定性一样，它还需要经验优化误差的控制，才能说明输出接近决策空间中的最优表现。

若 $A(S, U) \in \mathcal{W}$ 具有速率 $\bar{\rho}_n$ 的分布无关平均稳定性，并且

$$\mathbb{E}_{S,U}[\hat{R}_S(A(S, U)) - \inf_w \hat{R}_S(w)] \leq \rho_n.$$

定理 7.20 给出泛化代价 $g_n = \bar{\rho}_n$ ；代入定理 7.9 便有

$$\mathbb{E}_{S,U} R_{\mathcal{P}}(A(S, U)) - \inf_{w \in \mathcal{W}} R_{\mathcal{P}}(w) \leq \bar{\rho}_n + \rho_n. \quad (7.7)$$

若 $\bar{\rho}_n \rightarrow 0$ 且 $\rho_n \rightarrow 0$ ，则算法 PAC 学习此问题。条件 $\bar{\rho}_n + \rho_n \leq \varepsilon \delta$ 保证学习失败的概率不超过 δ 。

证明使用的是非负的超额期望风险，而不是直接对可能为负的泛化差应用 Markov 不等式。若只在某个固定分布下有相应上界，同样的推导给出该分布下的学习保证；要得到分布无关 PAC 结论，则须使两个速率都不依赖分布。

均值估计可以具体展示这种分布依赖。令 $z \in [0, 1]$ ，算法输出 $\bar{z}$ ，这次使用平方损失 $\ell(w, z) = (w - z)^2$ 。记总体均值为 μ 、方差为 σ^2 。对独立新观测，平方损失的期望为 $R_{\mathcal{P}}(\bar{z}) = \sigma^2 + (\bar{z} - \mu)^2$ ，因此

$$\mathbb{E}_S R_{\mathcal{P}}(\bar{z}) = \sigma^2 + \frac{\sigma^2}{n}.$$

样本内的恒等式 $\sum_i (z_i - \bar{z})^2 = \sum_i (z_i - \mu)^2 - n(\bar{z} - \mu)^2$ 则给出

$$\mathbb{E}_S \hat{R}_S(\bar{z}) = \sigma^2 - \frac{\sigma^2}{n}, \quad \gamma_n(A, \mathcal{P}) = \frac{2\sigma^2}{n}.$$

数据越集中，替换观测所造成的平均损失变化就越小。若所有观测都等于同一个数，则 $\sigma^2 = 0$ ，平均稳定性上界为零。若只利用 $z \in [0, 1]$ 这一范围条件，则 $\sigma^2 \leq 1/4$ 给出分布无关上界 $1/(2n)$ 。对 $w, w', z \in [0, 1]$ ，平方损失之差满足 $|(w - z)^2 - (w' - z)^2| = |w - w'| |w + w' - 2z| \leq 2|w - w'|$ 。替换一个观测使均值变化至多 $1/n$ ，所以同一算法的均匀稳定性可以用 $2/n$ 控制。平均分析在这里保留了最坏情形分析忽略的方差信息。样本均值恰好最小化平方损失的经验风险，所以 $\rho_n = 0$ 。平均稳定性因此给出超额期望风险的期望上界 $2\sigma^2/n$ ；直接计算的精确值为 $\mathbb{E}(\bar{z} - \mu)^2 = \sigma^2/n$ 。稳定性界在这个例子中给出了正确的收敛阶，但常数不一定最优。由 $\sigma^2 \leq 1/4$ ， $n \geq 1/(2\varepsilon\delta)$ 就是上述平均稳定性分析给出的 PAC 充分样本量。

均匀稳定性比平均稳定性要求更强，但在“是否存在某个能够学习的算法”这个问题上，两者给出相同的答案。

定理 7.21 一般学习基本定理的平均稳定性形式 在定理 7.18 的条件下，该问题分布无关 PAC 可学习，当且仅当存在始终 AERM 算法，具有分布无关平均稳定性，且 $\rho_n \rightarrow 0$ 、 $\bar{\beta}_n \rightarrow 0$ 。

证明. 充分性由定理 7.20 与定理 7.9 给出。对于必要性，前面的基本定理保证可学习问题存在均匀稳定的始终 AERM 算法；均匀稳定性又蕴含平均稳定性，因此同一个算法满足这里的条件。 ■

这里比较的是算法的存在性。对于一个已经给定的算法，平均稳定性并不自动加强为均匀稳定性；上述等价关系也不把一侧期望保证变成逐样本保证。

7.3.4 参数稳定性

前面的稳定性都比较损失。分析正则化或梯度下降时，我们往往先得到两次训练输出的参数相差多少，再判断这个距离会让损失改变多少。**参数稳定性** (argument stability, 也称 model stability) 直接衡量前一个距离。它需要在决策空间上指定距离；本小节取 $\mathcal{W} \subseteq \mathbb{R}^d$ ，用欧氏范数比较参数向量。平均参数稳定性在优化算法的精细泛化分析中尤为有用⁶。

定义 7.22 均匀参数稳定性 设算法 $A(S, U) \in \mathcal{W} \subseteq \mathbb{R}^d$ 。若对任意相邻样本 S, S' 都有

$$\mathbb{E}_U \|A(S, U) - A(S', U)\|_2 \leq \alpha_n,$$

则称算法具有速率 α_n 的均匀参数稳定性。两次运行使用相同的内部随机数 U 。

定义 7.23 平均参数稳定性 沿用定义 7.19 中的 $S, S^{(i)}$ 和 U 。若

$$\frac{1}{n} \sum_{i=1}^n \mathbb{E}_{S, S^{(i)}, U} \|A(S, U) - A(S^{(i)}, U)\|_2 \leq \bar{\alpha}_n(\mathcal{P}), \quad (7.8)$$

则称算法在分布 $\mathcal{P}$ 下具有速率 $\bar{\alpha}_n(\mathcal{P})$ 的平均参数稳定性。若同一个上界适用于所有允许分布，则称其为分布无关平均参数稳定性。

相同的 U 使比较只反映样本替换的影响。例如，在两份相邻样本上运行 SGD 时，使用相同的初始化和抽样索引序列。若改用两组独立随机数，

⁶ Y. Lei, Y. Ying, *Fine-Grained Analysis of Stability and Generalization for Stochastic Gradient Descent* In Proceedings of the 37th International Conference on Machine Learning, 2020, pp. 5809–5819

即使样本完全相同，两次输出也可能不同，这种距离还混入了算法自身的随机波动。均匀参数稳定性要求每一对相邻样本都满足上界，平均参数稳定性则允许上界依赖这些样本在 $\mathcal{P}$ 下的出现概率。

沿用均值估计的例子，替换第 i 项得到 $A(S^{(i)}) - A(S) = (z'_i - z_i)/n$ 。当观测位于 $[0, 1]$ 时，均匀参数稳定性上界为 $1/n$ ；平均参数稳定性却可以写成更具体的 $\mathbb{E}|z - z'|/n$ 。若 z 以概率 p 取 1、以概率 $1 - p$ 取 0，独立的 z, z' 只有取值不同时才产生距离 1，其概率为 $2p(1 - p)$ ，所以平均参数稳定性上界为 $2p(1 - p)/n$ 。这也解释了当数据几乎总取同一个值时，平均变化会远小于最坏情形变化。

要把参数距离转为损失差，需要控制损失对参数变化的敏感程度。损失关于参数是 L -Lipschitz，指对所有 $\mathbf{u}, \mathbf{v} \in \mathcal{W}$ 和 $z \in \mathcal{Z}$ 都有

$$|\ell(\mathbf{u}, z) - \ell(\mathbf{v}, z)| \leq L\|\mathbf{u} - \mathbf{v}\|_2. \quad (7.9)$$

它保证参数移动距离 r 时，任何一个观测上的损失变化都不超过 Lr 。因此，参数距离可以先转换为损失差，再用于比较经验风险与期望风险。

定理 7.24 参数稳定性与损失稳定性 设相关损失可积，且式 (7.9) 成立。若算法具有 α_n 均匀参数稳定性，则它具有对内部随机性平均后的 $L\alpha_n$ 均匀稳定性。若算法在 $\mathcal{P}$ 下具有 $\bar{\alpha}_n(\mathcal{P})$ 平均参数稳定性，则它具有速率 $L\bar{\alpha}_n(\mathcal{P})$ 的平均稳定性。

证明. 对任意相邻样本和任意观测，Lipschitz 条件给出

$$|\mathbb{E}_U \ell(A(S, U), z) - \mathbb{E}_U \ell(A(S', U), z)| \leq L \mathbb{E}_U \|A(S, U) - A(S', U)\|_2.$$

代入均匀参数稳定性上界得到第一项结论。对于平均稳定性，对定义 7.19 中的损失差逐项取绝对值，再使用 Lipschitz 条件，得到

$$|\gamma_n(A, \mathcal{P})| \leq \frac{L}{n} \sum_{i=1}^n \mathbb{E}_{S, z'_i, U} \|A(S^{(i)}, U) - A(S, U)\|_2 \leq L\bar{\alpha}_n(\mathcal{P}).$$

这也给出了平均稳定性所需的一侧上界。 ■

这个转换使前面的损失稳定性结论可以用于参数化算法。具体到期望风险与经验风险的偏差，需要区分一次训练后的泛化差 $R_{\mathcal{P}}(A(S, U)) - \hat{R}_S(A(S, U))$ ，以及对样本和算法随机性取平均得到的期望泛化差。平均参数稳定性直接控制后一个量，从而说明经验风险平均低估或高估期望风险的程度。

定理 7.25 参数稳定性与期望泛化差 设 $S \sim \mathcal{P}^n$, U 独立于样本, 相关损失可积, 且损失关于参数满足式 (7.9)。若算法在 $\mathcal{P}$ 下具有速率 $\bar{\alpha}_n(\mathcal{P})$ 的平均参数稳定性, 则

$$|\mathbb{E}_{S,U}[R_{\mathcal{P}}(A(S,U)) - \hat{R}_S(A(S,U))]| \leq L\bar{\alpha}_n(\mathcal{P}). \quad (7.10)$$

特别地, 期望风险满足

$$\mathbb{E}_{S,U}R_{\mathcal{P}}(A(S,U)) \leq \mathbb{E}_{S,U}\hat{R}_S(A(S,U)) + L\bar{\alpha}_n(\mathcal{P}).$$

若已知均匀参数稳定性上界 α_n , 则可将两式中的 $\bar{\alpha}_n(\mathcal{P})$ 替换为 α_n 。

证明. 替换样本恒等式 (7.6) 给出

$$\mathbb{E}_{S,U}[R_{\mathcal{P}}(A(S,U)) - \hat{R}_S(A(S,U))] = \gamma_n(A, \mathcal{P}).$$

前一定理的证明已经得到 $|\gamma_n(A, \mathcal{P})| \leq L\bar{\alpha}_n(\mathcal{P})$, 故第一式成立。取其上侧不等式, 并把平均经验风险移到右侧, 即得第二式。均匀参数稳定性对每对相邻样本都成立, 对这些样本取平均后仍成立, 故可取 $\bar{\alpha}_n(\mathcal{P}) \leq \alpha_n$ 。■

这里先对泛化差取期望, 再取绝对值, 不同训练结果的正负偏差仍可能相互抵消。因此, $L\bar{\alpha}_n(\mathcal{P})$ 不能直接作为某一次训练的泛化差绝对值上界。如果希望在观察一份样本之后, 用它的经验风险给期望风险加上高概率成立的上界, 则可以使用更强的均匀参数稳定性, 并对损失的取值范围作出限制。

定理 7.26 均匀参数稳定性的高概率泛化界 设 $S \sim \mathcal{P}^n$, $0 \leq \ell \leq 1$, 损失关于参数满足式 (7.9), 且确定性算法 A 具有速率 α_n 的均匀参数稳定性。对任意 $\delta \in (0, 1)$, 以至少 $1 - \delta$ 的样本概率, 有

$$|R_{\mathcal{P}}(A(S)) - \hat{R}_S(A(S))| \leq L\alpha_n + (2nL\alpha_n + 1)\sqrt{\frac{\log(2/\delta)}{2n}}.$$

证明. 由定理 7.24, 该算法具有 $L\alpha_n$ 均匀稳定性。将 $\beta_n = L\alpha_n$ 代入定理 7.16 即得结论。■

当 L 固定且 $\alpha_n = O(1/n)$ 时, 这个高概率上界随样本量增加而趋于零。较慢的稳定性速率可能需要前文介绍的精细集中分析, 不能仅凭 $\alpha_n \rightarrow 0$ 就断定上述公式右侧趋于零。对于随机算法, 定义 7.22 只控制内部随机性

平均后的参数距离；它可用于分析对内部随机性平均后的损失，但不能直接给出单次随机输出的上述高概率保证。

泛化差小表示经验评价接近期望风险，却没有说明这个共同的数值是否足够低。例如，在 $[0, 1]$ 上使用平方损失并始终输出 0，参数稳定性上界为零。若观测恒为 1，其经验风险和期望风险都等于 1，泛化差为零；决策 1 的期望风险却为零。这个算法没有学习成功，因为它没有降低经验风险。要得到可学习性，还需要保证算法输出的经验风险接近决策空间内的最优经验风险。

定理 7.27 参数稳定性与可学习性 设 $A(S, U) \in \mathcal{W}$ ，相关损失可积，损失关于参数满足式 (7.9)，其中 L 不依赖分布或样本量。若对所有允许分布，算法均具有平均参数稳定性上界 $\bar{\alpha}_n$ ，且满足

$$\mathbb{E}_{S,U} \left[\hat{R}_S(A(S, U)) - \inf_{\mathbf{w} \in \mathcal{W}} \hat{R}_S(\mathbf{w}) \right] \leq \rho_n,$$

其中 $\bar{\alpha}_n, \rho_n$ 均不依赖分布，则

$$\mathbb{E}_{S,U} R_{\mathcal{P}}(A(S, U)) - \inf_{\mathbf{w} \in \mathcal{W}} R_{\mathcal{P}}(\mathbf{w}) \leq L\bar{\alpha}_n + \rho_n.$$

若 $\bar{\alpha}_n \rightarrow 0$ 且 $\rho_n \rightarrow 0$ ，则算法分布无关 PAC 学习此问题。具体地， $L\bar{\alpha}_n + \rho_n \leq \varepsilon\delta$ 是达到精度 ε 与置信度 $1 - \delta$ 的充分样本量条件。均匀参数稳定性下可用 α_n 替换 $\bar{\alpha}_n$ 。

证明. 定理 7.25 给出 $g_n = L\bar{\alpha}_n$ 的期望泛化差上界。将它与题设的经验优化误差代入定理 7.9 即得全部结论。 ■

此处的 PAC 保证通过非负的超额期望风险得到，与前一个定理控制泛化差绝对值的方法不同。因此，推出可学习性不需要先证明那个高概率泛化界趋于零。若参数稳定性和经验优化误差的上界只在某个固定分布下成立，相同证明给出该分布下的学习保证；分布无关 PAC 结论则需要定理中的统一上界。

这些关系可以在前面的均值例子中同时算出。令 z 以概率 p 取 1、以概率 $1 - p$ 取 0， $\mathcal{W} = [0, 1]$ ，算法输出样本均值，并采用平方损失。在这个区域上可取 $L = 2$ ，而前面已得到 $\bar{\alpha}_n(\mathcal{P}) = 2p(1 - p)/n$ 。样本均值最小化平方损失的经验风险，所以 $\rho_n = 0$ 。定理 7.25 与定理 7.27 分别给出

$$\begin{aligned} |\mathbb{E}[R_{\mathcal{P}}(\bar{z}) - \hat{R}_S(\bar{z})]| &\leq \frac{4p(1 - p)}{n}, \\ \mathbb{E}R_{\mathcal{P}}(\bar{z}) - \inf_{w \in [0, 1]} R_{\mathcal{P}}(w) &\leq \frac{4p(1 - p)}{n}. \end{aligned}$$

虽然两个上界相同，左侧衡量的对象不同：第一式比较经验评价与总体评

价, 第二式比较输出与最优决策。由 $p(1-p) \leq 1/4$, $n \geq 1/(\varepsilon\delta)$ 是这条参数稳定性分析给出的分布无关 PAC 充分样本量。前面直接计算平均损失变化得到了更小的常数; 先用统一的 Lipschitz 常数转换参数距离, 可能使上界更宽松。

Lipschitz 条件在这里承担了必要的连接作用。例如, 分类器 $h_w(x) = \mathbf{1}\{x \geq w\}$ 的参数从 $-a$ 变为 a 时, 距离只有 $2a$; 但在 $x = 0, y = 1$ 处, 零一损失从 0 变为 1, 无论 $a > 0$ 多小都如此。因此, 参数接近本身不能保证零一损失接近。反过来, 损失稳定也不要求所有参数坐标都稳定: 若 $\ell((a, b), z) = (a - z)^2$ 完全不使用 b , 改变 b 不会改变任何损失。参数稳定性依赖参数表示和所选距离; 不能要求每个成功的学习算法都满足它。

平方损失在无界参数空间上没有统一的 Lipschitz 常数。为处理这类问题, 可以改为控制参数距离的平方平均, 并利用损失的光滑性。记

$$b_n^2(\mathcal{P}) = \frac{1}{n} \sum_{i=1}^n \mathbb{E}_{S, z_i', U} \|A(S^{(i)}, U) - A(S, U)\|_2^2.$$

$b_n(\mathcal{P})$ 是参数距离的均方根。Cauchy-Schwarz 不等式保证式 (7.8) 左侧不超过 $b_n(\mathcal{P})$, 因此控制均方根比只控制平均距离更强。下面的结果说明这种额外控制能带来什么。

定理 7.28 光滑损失下参数稳定性与期望泛化差 设 $\mathcal{W} = \mathbb{R}^d$, 算法 A 输出其中的参数。对任意 z , $\ell(\cdot, z)$ 在 $\mathbb{R}^d$ 上非负、可微且 M -光滑, 其中 $M > 0$, 即

$$\|\nabla \ell(\mathbf{u}, z) - \nabla \ell(\mathbf{v}, z)\|_2 \leq M \|\mathbf{u} - \mathbf{v}\|_2.$$

设相关损失可积, $b_n(\mathcal{P}) < \infty$, 并记 $r_n = \mathbb{E}_{S, U} \hat{R}_S(A(S, U)) < \infty$ 。则

$$\mathbb{E}_{S, U} [R_{\mathcal{P}}(A(S, U)) - \hat{R}_S(A(S, U))] \leq b_n(\mathcal{P}) \sqrt{2Mr_n} + \frac{M}{2} b_n^2(\mathcal{P}). \quad (7.11)$$

证明. 光滑性意味着对任意 $\mathbf{u}, \mathbf{v}$ 都有

$$\ell(\mathbf{v}, z) \leq \ell(\mathbf{u}, z) + \langle \nabla \ell(\mathbf{u}, z), \mathbf{v} - \mathbf{u} \rangle + \frac{M}{2} \|\mathbf{v} - \mathbf{u}\|_2^2.$$

令 $\mathbf{v} = \mathbf{u} - \nabla \ell(\mathbf{u}, z)/M$, 并利用左侧非负, 得到 $\|\nabla \ell(\mathbf{u}, z)\|_2^2 \leq 2M\ell(\mathbf{u}, z)$ 。再令 $\mathbf{u} = A(S, U)$ 、 $\mathbf{v} = A(S^{(i)}, U)$, 对 z_i 使用同一个光滑性不等式。对样本、替换观测、内部随机数和位置取平均, 内积项至多为

$$\left(\frac{1}{n} \sum_i \mathbb{E} \|\nabla \ell(A(S, U), z_i)\|_2^2 \right)^{1/2} b_n(\mathcal{P}) \leq \sqrt{2Mr_n} b_n(\mathcal{P}).$$

二次项平均为 $Mb_n^2(\mathcal{P})/2$ 。代入期望泛化差恒等式即得结论。 ■

这个界用实际输出的平均经验风险 r_n 代替了全局梯度范数上界，且不要求损失凸。在参数扰动相同的情况下，较小的 r_n 可以进一步减小上界；若参数扰动随训练增大，则仍要同时检查 $b_n(\mathcal{P})$ 。平均参数稳定性因而能表达数据和优化过程的影响，但不能仅凭经验风险下降就断言泛化改善。这里控制的是期望泛化差的一侧上界；将它与平均经验风险相加，就得到 $\mathbb{E}_{S,U} R_{\mathcal{P}}(A(S, U))$ 的上界。要进一步得到分布无关的学习保证，需要同时控制参数距离的均方根、平均经验风险和经验优化误差。

定理 7.29 光滑损失下参数稳定性与可学习性 在定理 7.28 的条件下，若存在不依赖分布的非负序列 b_n, c_n, ρ_n ，使所有允许分布均满足

$$b_n(\mathcal{P}) \leq b_n, \quad r_n \leq c_n, \\ \mathbb{E}_{S,U} [\hat{R}_S(A(S, U)) - \inf_{\mathbf{w}} \hat{R}_S(\mathbf{w})] \leq \rho_n,$$

则

$$\mathbb{E}_{S,U} R_{\mathcal{P}}(A(S, U)) - \inf_{\mathbf{w}} R_{\mathcal{P}}(\mathbf{w}) \\ \leq b_n \sqrt{2Mc_n} + \frac{M}{2} b_n^2 + \rho_n =: q_n.$$

若 $q_n \rightarrow 0$ ，则算法分布无关 PAC 学习此问题； $q_n \leq \varepsilon \delta$ 是达到精度 ε 与置信度 $1 - \delta$ 的充分样本量条件。

证明. 定理 7.28 给出 $g_n = b_n \sqrt{2Mc_n} + Mb_n^2/2$ 的期望泛化差上界。将它与经验优化误差 ρ_n 代入定理 7.9 即得结论。 ■

例如，若 M 固定、 $c_n \leq C < \infty$ ，则 $b_n \rightarrow 0$ 与 $\rho_n \rightarrow 0$ 足以使 $q_n \rightarrow 0$ 。如果平均经验风险的上界 c_n 随样本量增大，则还须检查 $b_n \sqrt{c_n}$ 是否趋于零。这说明光滑性可以替代全局 Lipschitz 条件，但需要保留损失大小对泛化分析的影响。后面正则化与 SGD 的证明将先控制参数距离，再使用本小节的结论分析期望风险与可学习性。

7.3.5 互信息稳定性

损失稳定性比较相邻样本上的损失，参数稳定性比较相邻样本上的参数距离。另一种分析从算法输出与训练样本之间的依赖出发：输出究竟保留了多少关于这份样本的信息。例如，一个算法始终输出同一个决策，其输出不包含样本信息；另一个算法把每个观测逐字保存下来，输出则保留了整份样本。信息论可以量化这两种情况之间的差别，而不必先为决策空间指定参数距离。

这条路线与“看过数据以后再选择”的偏差有关。Russo 与 Zou 用信息

量控制自适应数据分析中的选择偏差⁷。Xu 与 Raginsky 将输入样本与算法输出的互信息直接联系到期望泛化差⁸。为说明这些结论，需要先明确所比较的概率分布。

相对熵 (relative entropy)，也称 KL 散度，衡量一个概率分布相对于另一个分布的差异。它使用对数概率比：某种结果在两个分布下出现的概率相差越大，就越能区分这两个分布。

定义 7.30 相对熵 设 P, Q 为同一可测空间上的概率分布。若 P 关于 Q 绝对连续，则定义

$$D_{\text{KL}}(P||Q) = \int \log \frac{dP}{dQ} dP;$$

否则定义 $D_{\text{KL}}(P||Q) = +\infty$ 。本节对数均为自然对数。

绝对连续要求 Q 认为不可能发生的事件在 P 下也不发生； dP/dQ 是密度比。在离散情形，公式就是 $\sum_x P(x) \log(P(x)/Q(x))$ 。相对熵非负，且仅在两个分布相同时为零，但通常不对称，所以不是距离。

记随机输出为 $W = A(S, U)$ 。如果先抽取样本再训练，得到联合分布 $P_{S,W}$ ；如果分别按各自的边缘分布独立抽取 S 和 W ，得到乘积分布 $P_S \otimes P_W$ 。后者保留样本和输出各自的分布，却去掉两者的依赖。比较这两个分布，便得到 **互信息** (mutual information, MI)。

定义 7.31 互信息 随机元素 S, W 的互信息定义为

$$I(W; S) = D_{\text{KL}}(P_{S,W} || P_S \otimes P_W).$$

$I(W; S) = 0$ 当且仅当输出与样本独立。对学习算法而言，我们通常并不要求它完全忽略样本，而是要求保留的信息量相对于样本量增长得足够慢。本节采用如下输入—输出互信息的约定。

定义 7.32 互信息稳定性 设 $S \sim \mathcal{P}^n$ ， $W = A_n(S, U)$ ， U 独立于 S 。若存在不依赖 $\mathcal{P}$ 的非负序列 ι_n ，满足

$$I(W; S) \leq \iota_n \quad \text{对所有允许分布成立}, \quad \frac{\iota_n}{n} \longrightarrow 0,$$

则称算法序列具有分布无关的互信息稳定性。

这里要求的是每个观测平均对应的信息量趋于零，而不是总互信息必须趋于零。例如， ι_n 按 $\log n$ 增长仍满足定义。下面给出有界损失下的期望风险结论；更一般的次高斯损失版本可用相应的指数矩上界得到。

⁷ D. Russo, J. Zou, *Controlling Bias in Adaptive Data Analysis Using Information Theory* In Proceedings of the 19th International Conference on Artificial Intelligence and Statistics, 2016, pp. 1232–1240

⁸ A. Xu, M. Raginsky, *Information-Theoretic Analysis of Generalization Capability of Learning Algorithms* In Advances in Neural Information Processing Systems, 2017

定理 7.33 互信息与期望风险 设 $S \sim \mathcal{P}^n$, $W = A(S, U)$, U 独立于 S , 且 $0 \leq \ell \leq 1$ 。则

$$|\mathbb{E}[R_{\mathcal{P}}(W) - \hat{R}_S(W)]| \leq \sqrt{\frac{I(W; S)}{2n}}. \quad (7.12)$$

因此, $\mathbb{E}R_{\mathcal{P}}(W)$ 不超过 $\mathbb{E}\hat{R}_S(W) + \sqrt{I(W; S)/(2n)}$ 。

证明. 令 $P = P_{S, W}$, $Q = P_S \otimes P_W$, 并记 $g(S, W) = R_{\mathcal{P}}(W) - \hat{R}_S(W)$ 。在 Q 下, 给定 W 后, 样本仍然独立同分布, 所以 $\mathbb{E}_Q g = 0$ 。损失位于 $[0, 1]$, Hoeffding 引理给出

$$\log \mathbb{E}_Q e^{\lambda g} \leq \frac{\lambda^2}{8n}, \quad \lambda \in \mathbb{R}.$$

对任意 $\lambda > 0$, 改变分布的代价可由相对熵控制:

$$\lambda \mathbb{E}_P g \leq D_{\text{KL}}(P \| Q) + \log \mathbb{E}_Q e^{\lambda g}. \quad (7.13)$$

具体地, 定义 $dQ_\lambda/dQ = e^{\lambda g}/\mathbb{E}_Q e^{\lambda g}$, 展开 $D_{\text{KL}}(P \| Q_\lambda) \geq 0$ 便得到此式。因此 $\mathbb{E}_P g \leq I(W; S)/\lambda + \lambda/(8n)$ 。对 $-g$ 作相同推导, 再对 λ 取最优值得到结论。互信息为零时取极限; 互信息无穷时上界不提供有效保证。■

证明把真实训练过程与一个输出独立于样本的参照过程比较。参照过程的经验风险无偏, 互信息则控制引入样本依赖后, 平均偏差最多增加多少。这仍然是期望泛化差的界, 不能直接当作某一次训练的高概率误差上界。

定理 7.34 互信息稳定性与可学习性 在定理 7.33 的条件下, 设 $W \in \mathcal{W}$, 且对所有允许分布有

$$I(W; S) \leq \iota_n, \quad \mathbb{E}[\hat{R}_S(W) - \inf_w \hat{R}_S(w)] \leq \rho_n.$$

则

$$\mathbb{E}R_{\mathcal{P}}(W) - \inf_w R_{\mathcal{P}}(w) \leq \sqrt{\frac{\iota_n}{2n}} + \rho_n.$$

若 $\iota_n/n \rightarrow 0$ 且 $\rho_n \rightarrow 0$, 算法分布无关 PAC 学习此问题。条件 $\sqrt{\iota_n/(2n)} + \rho_n \leq \varepsilon\delta$ 足以保证 PAC 目标。

证明. 定理 7.33 给出 $g_n = \sqrt{\iota_n/(2n)}$ 的期望泛化差上界。将它与经验优化误差 ρ_n 代入定理 7.9 即得结论。■

若算法只可能输出预先给定的 K 个决策, 互信息至多为输出的熵

$H(W) = -\sum_w \mathbb{P}(W = w) \log \mathbb{P}(W = w)$, 而这个熵至多为 $\log K$ 。因此可以取 $t_n = \log K$ 。这从信息量的角度解释了有限候选范围为何有助于泛化。不过, 一个恒定输出的算法也有 $I(W; S) = 0$; 若它没有取得较小的经验优化误差, 互信息为零同样不能保证学到好的决策。

只看整份样本的信息量, 有时仍然过于粗略。Bu、Zou 与 Veeravalli 改为逐个考察输出与每个观测之间的互信息, 得到另一种期望风险上界⁹。

定理 7.35 逐观测互信息的期望风险界 在定理 7.33 的条件下,

$$|\mathbb{E}[R_{\mathcal{P}}(W) - \hat{R}_S(W)]| \leq \frac{1}{n} \sum_{i=1}^n \sqrt{\frac{I(W; z_i)}{2}}.$$

证明. 对每个 i , 比较 (W, z_i) 的联合分布与 $P_W \otimes \mathcal{P}$ 。在乘积分布下, $R_{\mathcal{P}}(W) - \ell(W, z_i)$ 的条件均值为零。沿用定理 7.33 中样本量为 1 的指数矩论证, 得到

$$|\mathbb{E}[R_{\mathcal{P}}(W) - \ell(W, z_i)]| \leq \sqrt{I(W; z_i)/2}.$$

对 n 项求和, 再用三角不等式即可。■

这个版本分别计算每个观测对输出的信息贡献。将右侧记为 $q_n(\mathcal{P})$, 加上经验优化误差就得到超额期望风险的期望上界 $q_n(\mathcal{P}) + \rho_n(\mathcal{P})$ 。若两项存在分布无关且趋于零的上界, 也能推出 PAC 可学习性。

普通互信息还有一个重要局限: 确定性算法精确输出连续数值时, $I(W; S)$ 可能无穷。例如, 在 $[0, 1]$ 上均匀抽样并输出样本均值, 平方损失下的期望泛化差为 $2\sigma^2/n$, 但输出的连续均值由 S 精确确定。联合分布集中在 $W = \bar{z}$ 上, 而独立乘积分布在这个集合上的概率为零, 所以互信息无穷。普通互信息界在这里失效, 并不意味着算法不能泛化。

Steinke 与 Zakynthinou 提出的条件互信息方法改变了信息比较的对象¹⁰。预先独立抽取 n 对观测, 每对中随机选一个用于训练。如果已经知道这 $2n$ 个观测, 输出额外揭示了哪些观测被选中, 才是需要衡量的信息。这样, 每一对的选择只有一个二元结果, 不会因观测包含连续实数就自动产生无限信息量。

定义 7.36 条件互信息 设所需条件分布存在。随机元素 W, B 在给定 V 时的条件互信息定义为

$$I(W; B | V) = \mathbb{E}_V D_{\text{KL}}(P_{W, B|V} \parallel P_{W|V} \otimes P_{B|V}).$$

在上述抽样构造中, 记全部备选观测为 $\tilde{S} = ((z_{i,0}, z_{i,1}))_{i=1}^n \sim \mathcal{P}^{2n}$ 。选择变量 $\mathbf{B} = (B_1, \dots, B_n)$ 独立均匀取自 $\{0, 1\}^n$, 训练样本是 $S_{\mathbf{B}} = (z_{1,B_1}, \dots, z_{n,B_n})$ 。

⁹ Y. Bu, S. Zou, V. V. Veeravalli, *Tightening Mutual Information-Based Bounds on Generalization Error* In IEEE Journal on Selected Areas in Information Theory, 2020, vol. 1, no. 1, pp. 121–130

¹⁰ T. Steinke, L. Zakynthinou, *Reasoning About Generalization via Conditional Mutual Information* In Proceedings of the Thirty Third Conference on Learning Theory, 2020, pp. 3437–3452

算法只接收这 n 个观测, 输出 $W = A(S_B, U)$, 其中 U 独立于 $\tilde{S}, \mathbf{B}$ 。图 7.2 展示了三个观测对的选择过程。




图 7.2 条件互信息的抽样构造。每列有两个独立观测, 选择变量决定哪一个进入训练样本。图中 $\mathbf{B} = (1, 0, 1)$, 选中的观测用底色和箭头同时标出。算法接收选中的三个观测与独立随机种子 U ; 条件互信息衡量已知全部六个观测时, 输出对选择变量揭示了多少信息。

定义 7.37 算法的条件互信息量 在上述构造下, 算法在分布 $\mathcal{P}$ 下的条件互信息量定义为

$$\kappa_n(A, \mathcal{P}) = I(W; \mathbf{B} | \tilde{S}).$$

若存在不依赖分布的 κ_n , 使所有允许分布满足 $\kappa_n(A, \mathcal{P}) \leq \kappa_n$ 且 $\kappa_n/n \rightarrow 0$, 则称算法序列具有分布无关的条件互信息稳定性。

选择变量只有 2^n 种可能, 因此 $0 \leq \kappa_n(A, \mathcal{P}) \leq n \log 2$ 。这个有限上界避免了连续输出导致的无穷大, 但仍然与 n 成正比, 单凭它不足以保证泛化差趋于零。有用的结论需要进一步控制算法实际揭示了多少选择信息。

定理 7.38 条件互信息与期望风险 设 $0 \leq \ell \leq 1$, 沿用定义 7.37 的构造。则

$$|\mathbb{E}[R_{\mathcal{P}}(W) - \hat{R}_{S_B}(W)]| \leq \sqrt{\frac{2\kappa_n(A, \mathcal{P})}{n}}.$$

证明. 用每对中未被选中的观测评价输出, 并减去经验风险, 记

$$g(\tilde{S}, \mathbf{B}, W) = \frac{1}{n} \sum_{i=1}^n [\ell(W, z_{i,1-B_i}) - \ell(W, z_{i,B_i})].$$

在真实联合分布 P 下, 未选观测独立于训练样本和算法内部随机数, 所以 $\mathbb{E}_P g = \mathbb{E}[R_{\mathcal{P}}(W) - \hat{R}_{S_B}(W)]$ 。构造参照分布 Q : 保留 $(\tilde{S}, W)$ 的联合分布, 但在给定 $\tilde{S}$ 后独立、均匀地重新抽取 B 。于是 $D_{\text{KL}}(P||Q) = \kappa_n(A, \mathcal{P})$ 。

在 Q 下, 给定 $\tilde{S}, W$, 每一对的损失差随 B_i 以相同概率取正负两个值, 且绝对值不超过 1。各项独立, 因此 $\log \mathbb{E}_Q e^{\lambda g} \leq \lambda^2 / (2n)$ 。将此式用于式 (7.13), 对正负两个方向分别取最优 λ , 得出结论。 ■

若算法在固定分布 $\mathcal{P}$ 下的平均经验优化误差不超过 $\rho_n(\mathcal{P})$, 同一风险分解给出超额期望风险上界 $\sqrt{2\kappa_n(A, \mathcal{P})/n} + \rho_n(\mathcal{P})$ 。若进一步存在不依赖分布的上界 κ_n 与 ρ_n , 且 $\kappa_n/n \rightarrow 0$ 、 $\rho_n \rightarrow 0$, 则定理 7.9 给出 PAC 可学习性; 充分条件为 $\sqrt{2\kappa_n/n} + \rho_n \leq \varepsilon\delta$ 。条件互信息能够容纳连续参数, 但它与普通互信息使用不同的参照过程; 不能只把前一个界中的 $I(W; S)$ 换成 κ_n 而保留常数和所有结论。条件互信息还可以与始终 AERM 结合, 给出一个与前面基本定理对应的存在性刻画。

定理 7.39 条件互信息稳定性与可学习性 在定理 7.18 的条件下, 该问题分布无关 PAC 可学习, 当且仅当存在始终 AERM 算法, 具有分布无关的条件互信息稳定性。

证明. 充分性由定理 7.38 与定理 7.9 给出。为证必要性, 使用一般学习基本定理证明中的构造: 从 n 个位置中有放回地随机抽取 $k = \lfloor \sqrt{n} \rfloor$ 个位置, 再调用已有学习算法。该构造已经保证始终 AERM。

记抽样索引为 $J = (J_1, \dots, J_k)$, 原学习算法的内部随机数为 U_0 。在给定 $\tilde{S}, J, U_0$ 时, 新算法的输出仅由被访问位置的选择变量 $(B_{J_1}, \dots, B_{J_k})$ 决定。每个选择变量至多包含 $\log 2$ 的信息量, 故

$$\begin{aligned} I(W; \mathbf{B} | \tilde{S}) &\leq I(W, J, U_0; \mathbf{B} | \tilde{S}) \\ &= I(W; \mathbf{B} | \tilde{S}, J, U_0) \leq k \log 2. \end{aligned}$$

等式使用 J, U_0 与 $\tilde{S}, \mathbf{B}$ 独立; 最后一步使用互信息不超过决定输出的离散选择变量的熵。因此可取 $\kappa_n = k \log 2$, 并有 $\kappa_n/n \rightarrow 0$ 。 ■

必要性同样允许重新构造算法; 它没有要求原来的每个成功算法都具有较小条件互信息。这一刻画也不能换成普通互信息, 因为后者仍可能记录连续观测的无限精度。

7.3.6 稳定性的关系与边界

前文已经从扰动对象、比较对象、平均方式和保证类型区分了各类稳定性。学完这些定义后, 还需要判断它们之间哪些关系可以推出, 哪些只因名称

相近而容易混淆。只有在相应定理的条件下，稳定性代价才能与经验优化误差相加，得到超额期望风险的期望上界。


在同一种替换操作下，均匀损失控制可以推出平均损失控制；统一的 Lipschitz 条件又使均匀参数稳定性推出均匀稳定性，使平均参数稳定性推出平均稳定性。留一法改变样本量，不能仅因也使用“稳定性”一词就与替换型条件互换。若只知道参数距离接近，也不能省略把参数距离转换成损失差的条件。

互信息与损失稳定性之间没有这样的直接强弱排序。前面的连续均值算法具有趋于零的均匀稳定性，普通互信息却无穷。反过来，令 $z_i \in \{0, 1\}$ ，算法仅在所有观测均为 1 时输出 $W = 1$ ，否则输出 0，并用损失 $\ell(w, z) = w$ 评价。输出只有两种可能，所以 $I(W; S) \leq \log 2$ ；但把全 1 样本中的一项改为 0，损失会从 1 变为 0，均匀稳定性常数始终为 1。信息量小并不意味着每一对相邻样本的损失都接近。

更关键的区分是“能够估计期望风险”与“能够学习”。上例在观测恒为 1 的分布下始终输出 1，而决策 0 的期望风险为零，因而虽然互信息很小，仍不能学习这个问题。它缺少的是经验最优性。类似地，一个固定输出的算法可以同时满足多种稳定性条件，却始终选择较差的决策。

对于学习问题是否可学习，定理 7.18、定理 7.21 与定理 7.39 分别给出了均匀稳定、平均稳定和条件互信息稳定的始终 AERM 算法的存在性刻画。留一法、参数稳定性和普通互信息条件提供其他验证途径。这些存在性结论与充分条件，都不能改写为对每个成功算法的必要要求。图 7.3 把共同的证明目标与一致收敛方法放在一起比较。

空间层面的控制



算法层面的控制




图 7.3 期望风险的两条分析路线。上方同时控制整个决策空间，下方控制算法输出的期望泛化差；两条路线都要结合经验最优性。下方用 β_n 泛指所选稳定性定理提供的代价项。

7.4 凸学习问题

前面的学习保证没有使用凸性。为了构造既稳定又能降低经验风险的具体算法，本节对决策空间和损失函数增加凸性条件。正则化通过目标的曲率控制最优解变化，随机梯度下降则通过逐步比较两条迭代轨迹控制变化，再分别加入经验优化误差。这也说明，学习理论不仅能判断已有算法，还能帮助设计算法。在凸损失下，适当的强凸惩罚项可以使最优解对样本变化更不敏感，而无须缩小原有决策空间。惩罚项同时可能使训练结果偏离原有经验风险的最小解，因此需要一起计算稳定性收益与正则化代价。

7.4.1 凸性与损失函数

训练分类器时，不仅需要知道预测是否正确，还需要知道怎样调整参数才能改善预测。设真实标签为 $+1$ ，分类分数从 -2 提高到 -0.1 ，模型虽然更接近正负分界点，却仍被零一损失记作同一次错误。分数没有跨过零点时，零一损失不能通过梯度反映这一变化；作为分数的函数，它既不连续也不凸。将标签编码为 $y \in \{-1, 1\}$ 后，线性分类常以合页损失 $\max\{0, 1 - y\mathbf{w}^\top \mathbf{x}\}$ 或逻辑损失 $\log(1 + e^{-y\mathbf{w}^\top \mathbf{x}})$ 替代它。在上述例子中，合页损失从 3 降至 1.1，因而能反映分数的改善。分数达到 1 时，合页损失才降为零，它还要求正确预测留出一定间隔。对线性参数而言，这些替代损失是凸的，便

于使用凸优化方法，但优化的是另一个总体目标；只有在适当的**分类校准** (classification calibration) 条件下，替代损失下的期望风险趋近最优才能推出零一损失下的期望风险趋近最优。

分类校准可以从固定输入下的条件替代风险理解：这里的条件替代风险，是在给定输入 x 时，按标签的条件分布计算的替代损失期望。记 $\eta(x) = \mathbb{P}(y = 1 | x)$ ，分别计算预测正分数和负分数时的条件替代风险。如果 $\eta(x) > 1/2$ ，条件替代风险的最优分数应为正；若 $\eta(x) < 1/2$ ，最优分数应为负。例如，在某个输入上正标签概率为 0.7，预测正类的条件错误率为 0.3，预测负类则为 0.7；校准的替代损失应当使其最优分数也选择正号。校准要求替代目标在每个 x 上都偏好贝叶斯分类器的符号。凸性帮助求解替代目标，校准性则联系不受限的替代损失下的最优期望风险与贝叶斯风险。若只在受限的线性类内优化，类内替代损失下期望风险的最小解不必也是类内零一损失下期望风险的最小解；此时还需要分析函数空间的近似能力，不能把校准性当作两个受限优化问题等价的保证。

凸学习允许在两个可行决策之间作插值，并要求插值的损失不超过两端损失的加权平均。本节先固定一个实赋范线性空间 $(V, \|\cdot\|)$ ，并令 $\mathcal{W} \subseteq V$ ；除非后文明确改用欧氏空间，凸性、Lipschitz 性和强凸性都相对于这个空间及同一个范数理解。

定义 7.40 凸学习问题 若 $\mathcal{W}$ 是凸集，并且对每个 $z \in Z$ ，函数 $w \mapsto \ell(w, z)$ 为凸函数，则称该一般学习问题为凸学习问题。也就是说，对任意 $u, v \in \mathcal{W}$ 、 $t \in [0, 1]$ 和 $z \in Z$ ，有

$$\ell(tu + (1-t)v, z) \leq t\ell(u, z) + (1-t)\ell(v, z).$$

凸性约束损失曲面的形状，却不限制它变化得有多快。要从两个决策接近推断它们的损失接近，还需要控制损失的变化率。

Lipschitz 条件用一个固定常数限制变化率。例如，决策移动 0.01 而 $L = 2$ 时，同一观测上的损失变化最多为 0.02。

定义 7.41 Lipschitz 损失 若对任意 w, w' 与 z 都满足

$$|\ell(w, z) - \ell(w', z)| \leq L\|w - w'\|, \quad (7.14)$$

则称损失关于该范数是 L -Lipschitz 的。

损失对预测值凸不必然意味着对网络参数凸；这里的凸性明确针对决策变量 w 。对 Hilbert 空间中的线性预测，若 $\|w\| \leq B$ 、 $\|x\| \leq r$ 且标量预测对应的损失为 L -Lipschitz，式 (5.15) 给出 $LB r / \sqrt{n}$ 量级的维数无关泛化项。关键是范数约束和损失结构，而非“参数空间无限维”本身。

7.4.2 凸学习问题的正则化

强凸正则化通过限制解对单条数据的敏感度，提供稳定性与经验拟合之间的明确权衡。取 $\lambda > 0$ ，考虑正则化 ERM

$$A(S) \in \arg \min_{w \in \mathcal{W}} \{\hat{R}_S(w) + \lambda \Omega(w)\}. \quad (7.15)$$

强凸性要求目标曲面比普通凸函数多出一一定的弯曲程度，不能在一整段不同决策之间保持平坦。具体地，若目标函数满足对所有 u, v 和 $t \in [0, 1]$,

$$F(tu + (1-t)v) \leq tF(u) + (1-t)F(v) - \frac{\mu}{2}t(1-t)\|u - v\|^2, \quad (7.16)$$

则称其为 μ -强凸。曲率把目标值的微小变化转成解距离的上界。

普通凸函数可以有一整段平坦的最小值。替换一个样本后，算法可能从平坦区域的一端跳到另一端，经验目标几乎不变，预测却变化很大。强凸性排除了这种平坦方向：离最小点距离为 r 时，目标至少付出与 μr^2 同阶的代价。正则项因而不只表达“偏好小参数”，还给最优解提供了抵抗数据扰动的曲率。

一个可直接求解的例子是正则化均值估计。对 $z_i \in [0, 1]$ ，最小化

$$\frac{1}{2n} \sum_{i=1}^n (w - z_i)^2 + \frac{\lambda}{2} w^2$$

得到 $\hat{w} = \bar{z}/(1+\lambda)$ 。替换一条观测最多使解改变 $1/[n(1+\lambda)]$ 。增大 λ 确实减小了数据替换的影响，但也把估计值向零拉近；若总体均值远离零，这种收缩会产生偏差。一般的稳定性证明将用强凸性和 Lipschitz 条件表达同样的权衡，而不依赖解能否显式写出。

定理 7.42 强凸正则化的稳定性 设 $\mathcal{W}$ 是实赋范线性空间 $(V, \|\cdot\|)$ 中的非空凸集。每个 $\ell(\cdot, z)$ 都在 $\mathcal{W}$ 上凸，并相对于同一范数为 L -Lipschitz； Ω 也在 $\mathcal{W}$ 上相对于该范数为 1-强凸。若式 (7.15) 的最小解存在，则其强凸性使最小解唯一，算法 A 具有

$$\beta_n \leq \frac{2L^2}{\lambda n} \quad (7.17)$$

的均匀稳定性。

证明. 记相邻样本的解为 w, w' ，相应正则目标为 $F_S, F_{S'}$ 。最优性和 λ -强凸性给出

$$F_S(w') - F_S(w) \geq \frac{\lambda}{2} \|w - w'\|^2, \quad F_{S'}(w) - F_{S'}(w') \geq \frac{\lambda}{2} \|w - w'\|^2.$$

相加后共同的 $n - 1$ 个损失与正则项抵消, 剩余两项由 Lipschitz 性至多为 $2L\|w - w'\|/n$ 。故 $\|w - w'\| \leq 2L/(\lambda n)$ 。对任意测试观测 z , 同一范数下的 Lipschitz 条件直接给出

$$|\ell(w, z) - \ell(w', z)| \leq L\|w - w'\| \leq \frac{2L^2}{\lambda n},$$

即得到所述均匀稳定性上界。 ■

较大的 λ 增强稳定性, 却也加大正则化偏差。岭回归取 $\Omega(w) = \|w\|_2^2/2$ 。平方损失并非全局 Lipschitz; 只有在 $\|x\|$ 、 $|y|$ 及 $\|w\|$ 受控时, 残差有界, 才能为所处区域给出有限的 L 。省略这些条件会把局部有效的结论误写成全局保证。

稳定性只完成了期望风险估计的一步, 还要比较经验目标。正则化算法最小化的是经验风险与正则项之和, 所以它的经验风险可能高于未经正则化的最小值。下面保留这一差额, 明确正则化提高稳定性所付出的代价。

定理 7.43 正则化学习的期望风险保证 在定理 7.42 的条件下, 进一步设 $\Omega \geq 0$ 且相关损失可积。则对任意固定 $w \in \mathcal{W}$,

$$\mathbb{E}_S R_{\mathcal{P}}(A(S)) - R_{\mathcal{P}}(w) \leq \frac{2L^2}{\lambda n} + \lambda \Omega(w). \quad (7.18)$$

若 $\mathcal{W}$ 为 Hilbert 空间中半径为 $B > 0$ 的闭球, $\Omega(w) = \|w\|^2/2$, 且 $L > 0$, 取 $\lambda = 2L/(B\sqrt{n})$ 可得

$$\mathbb{E}_S R_{\mathcal{P}}(A(S)) - \inf_{w \in \mathcal{W}} R_{\mathcal{P}}(w) \leq \frac{2LB}{\sqrt{n}}.$$

证明. 正则化目标的最优性给出

$$\hat{R}_S(A(S)) + \lambda \Omega(A(S)) \leq \hat{R}_S(w) + \lambda \Omega(w).$$

去掉左侧非负的正则项, 对样本取期望, 再加上稳定性控制的期望泛化差, 得到第一式。在半径 B 的闭球上, $\Omega(w) \leq B^2/2$ 。代入所给 λ 后, 稳定性项与正则化比较项均不超过 $LB/\sqrt{n}$ 。对 w 取下确界得到第二式。 ■

增大 λ 减小稳定性项, 却增大正则化比较项。后一项是这一分析对正则化偏差的上界, 并不是精确的偏差值。两个上界的平衡给出 $1/\sqrt{n}$ 的平均超额期望风险速率。由于算法输出仍在比较空间内, Markov 不等式进一步给出: $n \geq (2LB/(\epsilon\delta))^2$ 足以保证 PAC 目标。这个充分样本量并未优化置信度依赖。

上述保证不显含空间维度, 但依赖有限的范数半径和 Lipschitz 常数。它讨论的是受这些条件约束的实值损失学习, 不能据此推断无限 VC 维的无

约束零一分类问题也可学习。对平方损失，必须先检查数据与决策的范围是否使这些条件成立。

7.4.3 凸学习问题的随机梯度下降

随机梯度下降 (stochastic gradient descent, SGD) 把每一步优化限制为一个样本的梯度。例如，用单个观测的平方损失 $\ell(w, z) = (w - z)^2/2$ 估计均值，梯度为 $w - z$ 。从 $w = 0.5$ 出发、步长取 0.1，抽到 $z = 0$ 会把参数更新为 0.45，抽到 $z = 1$ 则更新为 0.55。每一步根据当前抽到的观测移动，完整训练结果因而依赖抽样顺序。这个数值例子说明更新机制；下面的稳定性界还需要额外的凸性、光滑性与 Lipschitz 条件。

在固定样本上令 i_t 独立均匀取自 $\{1, \dots, n\}$ ，从相同的确定初值出发，更新为

$$\mathbf{w}^{(t+1)} = \mathbf{w}^{(t)} - \eta_t \nabla \ell(\mathbf{w}^{(t)}, z_{i_t}), \quad t = 0, \dots, T-1. \quad (7.19)$$

这里每个损失在欧氏空间上凸、 L -Lipschitz，并且 M -光滑，即其梯度满足 $\|\nabla \ell(\mathbf{u}, z) - \nabla \ell(\mathbf{v}, z)\|_2 \leq M \|\mathbf{u} - \mathbf{v}\|_2$ 。若每步使用从总体新抽出的观测，分析的是另一个随机逼近问题；本节关心反复访问固定样本时产生的数据依赖。

定理 7.44 凸光滑 SGD 的稳定性 设每个损失在欧氏空间上凸、 L -Lipschitz 且 M -光滑， $M > 0$ 。使用式 (7.19)、相同的确定初值及 $0 \leq \eta_t \leq 2/M$ ，则最后一步输出对算法内部随机性平均后的均匀稳定性满足

$$\beta_n \leq \frac{2L^2}{n} \sum_{t=0}^{T-1} \eta_t.$$

证明. 在相邻样本上使用同一索引序列，可以逐步比较两条轨迹。凸光滑函数的梯度满足

$$\langle \nabla \ell(\mathbf{u}, z) - \nabla \ell(\mathbf{v}, z), \mathbf{u} - \mathbf{v} \rangle \geq \frac{1}{M} \|\nabla \ell(\mathbf{u}, z) - \nabla \ell(\mathbf{v}, z)\|_2^2.$$

将一次梯度更新后的距离平方展开可知，当 $0 \leq \eta_t \leq 2/M$ 时，同一损失的梯度映射不扩大距离。因此，未抽中替换位置时，两条轨迹不会产生新的距离；抽中时，梯度范数至多 L ，可用三角不等式把新增距离上界为 $2\eta_t L$ 。

记 $d_t = \mathbb{E} \|\mathbf{w}^{(t)} - \mathbf{w}^{(t)}\|_2$ ，期望对共同索引序列取。抽中替换位置的概率为 $1/n$ ，所以 $d_{t+1} \leq d_t + 2\eta_t L/n$ ，且 $d_0 = 0$ 。递推和 Lipschitz 条件给出

$$d_T \leq \frac{2L}{n} \sum_{t=0}^{T-1} \eta_t, \quad \beta_n \leq \frac{2L^2}{n} \sum_{t=0}^{T-1} \eta_t. \quad (7.20)$$

■

这里的 d_T 是对每一对相邻样本成立的参数距离上界，因而先给出均匀参数稳定性。再由损失的 Lipschitz 条件得到均匀稳定性，便可使用第 7.3 节的期望泛化差结论。

迭代次数和步长同时影响优化误差与泛化差。较早停止会减小式 (7.20) 的上界，却可能留下较大的经验优化误差；较晚停止则相反。因此早停是需要平衡两项误差的选解机制，不能仅从稳定性界断定训练越短越好。凸与非凸 SGD 的代表性稳定性分析由 Hardt、Recht 与 Singer 给出¹¹。

一般凸损失的梯度更新不放大已有扰动，但每次访问被替换的观测仍可能增加新扰动。强凸损失还会缩小已有距离，使过去产生的影响逐渐衰减，因此能得到不随训练轮数增长的稳定性上界。下面在有界的可行区域上陈述，避免将全局强凸性与全局有界梯度混为一谈。

定理 7.45 强凸投影 SGD 的稳定性 设 $\mathcal{W}$ 是非空闭凸集。每个损失在其邻域内二阶连续可微，且在 $\mathcal{W}$ 上满足

$$\mu \mathbf{I} \leq \nabla^2 \ell(\mathbf{w}, z) \leq M \mathbf{I}, \quad \|\nabla \ell(\mathbf{w}, z)\|_2 \leq L,$$

其中 $0 < \mu \leq M$ 。投影 SGD 从相同的确定初值出发，以固定步长 $0 < \eta \leq 1/M$ 独立均匀访问样本。则 T 步输出的随机性平均后的均匀稳定性满足

$$\beta_{n,T} \leq \frac{2L^2}{\mu n} (1 - (1 - \mu\eta)^T) \leq \frac{2L^2}{\mu n}.$$

证明. 沿两参数之间的线段对 Hessian 积分，梯度更新的差等于 $(\mathbf{I} - \eta \mathbf{H})(\mathbf{u} - \mathbf{v})$ ，其中 $\mathbf{H}$ 的特征值位于 $[\mu, M]$ 。所以同一观测的更新将距离至多乘以 $1 - \mu\eta$ 。投影不扩大距离。抽中替换位置时，再增加至多 $2L\eta$ 的扰动，故

$$D_{t+1} \leq (1 - \mu\eta)D_t + \frac{2L\eta}{n}, \quad D_0 = 0.$$

求和该几何级数，再乘损失的 Lipschitz 常数 L ，即得结论。 ■

这里每个单样本损失都满足曲率下界；仅知道平均经验风险强凸，不能直接得到每一步的收缩。加入二次正则项也可以提供曲率，但梯度范数、光滑常数和比较目标都必须相应更新。这个结果解释了强凸性为何可以允许更长时间训练，同时仍需单独检查经验优化误差。

仅有稳定性界不能确定何时停止训练，还需要经验优化误差的上界。为了给出完整结论，下面采用投影 SGD，并输出迭代点的平均值。投影把每步结果限制在指定的参数球内，平均则利用凸性把各步的损失保证转给最终输出。这与直接输出最后一次迭代是两种不同的算法约定。

¹¹ M. Hardt, B. Recht, Y. Singer, *Train Faster, Generalize Better: Stability of Stochastic Gradient Descent* In Proceedings of the 33rd International Conference on Machine Learning, 2016, pp. 1225–1234

定理 7.46 平均投影 SGD 的期望风险保证 设损失满足定理 7.44 的条件且相关损失可积。令 $\mathcal{W} = \{\mathbf{w} : \|\mathbf{w}\|_2 \leq B\}$, 初值 $\mathbf{w}^{(0)} = \mathbf{0}$, 并使用固定步长 $0 < \eta \leq 2/M$ 及更新

$$\mathbf{w}^{(t+1)} = \Pi_{\mathcal{W}}(\mathbf{w}^{(t)} - \eta \nabla \ell(\mathbf{w}^{(t)}, z_{i_t})), \quad \bar{\mathbf{w}} = \frac{1}{T} \sum_{t=0}^{T-1} \mathbf{w}^{(t)}.$$

其中 $\Pi_{\mathcal{W}}$ 为欧氏投影, i_t 独立均匀取自样本索引。则

$$\mathbb{E}_{S,U} R_{\mathcal{P}}(\bar{\mathbf{w}}) - \inf_{\mathbf{w} \in \mathcal{W}} R_{\mathcal{P}}(\mathbf{w}) \leq \frac{2L^2 \eta T}{n} + \frac{B^2}{2\eta T} + \frac{\eta L^2}{2}.$$

若 $B, L > 0$, 取 $T = n$ 和 $\eta = B/(L\sqrt{n}) \leq 2/M$, 右侧不超过 $3LB/\sqrt{n}$ 。

证明. 投影不扩大距离, 因此定理 7.44 的轨迹比较仍成立。平均迭代点间的距离不超过各步距离的平均值, 再用 Lipschitz 条件, 得到平均输出的稳定性上界 $2L^2 \eta T/n$ 。

为比较经验风险, 固定样本 S 及比较参数 $\mathbf{w} \in \mathcal{W}$, 记随机梯度为 $\mathbf{g}_t$ 。展开更新距离的平方, 并用投影不扩大到可行点的距离, 得到

$$2\eta \langle \mathbf{g}_t, \mathbf{w}^{(t)} - \mathbf{w} \rangle \leq \|\mathbf{w}^{(t)} - \mathbf{w}\|_2^2 - \|\mathbf{w}^{(t+1)} - \mathbf{w}\|_2^2 + \eta^2 L^2.$$

给定此前迭代结果, $\mathbb{E}[\mathbf{g}_t] = \nabla \hat{R}_S(\mathbf{w}^{(t)})$ 。凸性使内积的条件期望不小于 $\hat{R}_S(\mathbf{w}^{(t)}) - \hat{R}_S(\mathbf{w})$ 。对 t 求和后, 中间的距离平方相消; 初始距离至多 B , 所以

$$\frac{1}{T} \sum_{t=0}^{T-1} \mathbb{E}_U \hat{R}_S(\mathbf{w}^{(t)}) - \hat{R}_S(\mathbf{w}) \leq \frac{B^2}{2\eta T} + \frac{\eta L^2}{2}.$$

由凸性, 平均参数的经验风险不超过左侧各次经验风险的平均。再结合稳定性给出的期望泛化差, 并对固定比较参数取下确界, 即得结论。 ■

这个定理把三项代价放在同一个式子中: 第一项来自样本扰动对算法的影响, 第二项反映迭代尚未充分降低经验风险, 第三项来自固定步长的随机梯度误差。在所给参数选择下, 三项均为 $1/\sqrt{n}$ 量级, 因此得到分布无关的学习保证。最后一步输出与平均输出、固定样本反复访问与每步抽取新观测, 分别需要对应的分析, 不能在说明时交换使用。

7.5 非凸学习问题

7.5.1 非凸性带来的变化

非凸学习仍然使用相同的期望风险目标, 只是不再要求每个 $\ell(\cdot, z)$ 关于参数凸。例如, 预测函数为 $h_w(x) = w^2 x$ 、观测为 $(x, y) = (1, 1)$ 时, 平方损

失为 $(w^2 - 1)^2$ 。它有两个最小点 $w = \pm 1$ ，而 $w = 0$ 处的梯度也为零，损失却为 1。所以“梯度很小”和“经验风险接近最优”已经不是同一个条件。这个多项式例子用于说明非凸形状；它在整个实数轴上不满足后面定理所需的全局 Lipschitz 条件。

凸 SGD 的证明还使用了另一条性质：同一梯度更新不会放大两组参数之间的距离。一般非凸函数只满足较弱的上界。若梯度为 M -Lipschitz，定义 $G_{z,\eta}(\mathbf{w}) = \mathbf{w} - \eta \nabla \ell(\mathbf{w}, z)$ ，则三角不等式给出

$$\|G_{z,\eta}(\mathbf{u}) - G_{z,\eta}(\mathbf{v})\|_2 \leq (1 + M\eta)\|\mathbf{u} - \mathbf{v}\|_2.$$

一次样本替换造成的差异，可能被后续更新继续放大。图 7.4 把两组参数放在同一个二维平面上，直接比较一次梯度更新前后的距离。三个例子使用相同的初值和步长，只改变目标函数的曲率：负曲率使两点分开，平坦方向保留原有距离，正曲率则把两点拉近。




图 7.4 同一梯度更新如何影响参数距离。三个参数平面使用相同尺度，初值均为 $\mathbf{w} = (1, 2)^\top$ 、 $\mathbf{w}' = (3, 2)^\top$ ，步长均为 $\eta = 1/2$ 。空心标记表示初值，实心标记表示 $\mathbf{w}^+ = \mathbf{w} - \eta \nabla f(\mathbf{w})$ 及 $\mathbf{w}'^+$ ；箭头表示各自的梯度步，虚线和实线连接更新前后的两点。图中二次函数的梯度步给出精确距离 $D^+ = 3, 2, 1$ ，并非一般情形的距离等式。凸且 M -光滑时， $\eta \leq 2/M$ 保证不扩张；满足本章强凸光滑条件时， $\eta \leq 1/M$ 保证至多以 $1 - \mu\eta$ 收缩。仅有光滑性不能排除扩张。

稳定性的替换样本恒等式不依赖凸性，因此仍能从轨迹距离推出期望泛化差。失去的是自动得到较小轨迹距离和较小经验优化误差的保证，下面分别处理这两个问题。

7.5.2 非凸学习问题的正则化

非凸情形下，二次正则项能够抵消一部分负曲率，但正则化强度必须与负曲率的大小比较。称 F 为 κ -弱凸的，是指加上 $\kappa\|\mathbf{w}\|_2^2/2$ 以后变为凸函数。例如， $-\kappa w^2/2$ 恰好需要这么大的二次项才能变平；小于这个强度的正则

项仍然留下负曲率。二阶可微时，弱凸条件等价于 Hessian 的特征值不小于 $-\kappa$ 。

定义 7.47 弱凸函数 设 $\mathcal{W}$ 是欧氏空间中的凸集， $\kappa \geq 0$ 。若 $\mathbf{w} \mapsto F(\mathbf{w}) + \kappa \|\mathbf{w}\|_2^2/2$ 在 $\mathcal{W}$ 上为凸函数，则称 F 在 $\mathcal{W}$ 上为 κ -弱凸函数。

定理 7.48 弱凸损失的正则化稳定性 设 $\mathcal{W}$ 为半径 B 的闭球，每个损失在其中为 κ -弱凸且 L -Lipschitz。取 $\lambda > \kappa$ ，假设正则化目标的最小解存在，令

$$A_\lambda(S) = \arg \min_{\mathbf{w} \in \mathcal{W}} \left\{ \hat{R}_S(\mathbf{w}) + \frac{\lambda}{2} \|\mathbf{w}\|_2^2 \right\}.$$

则 A_λ 具有均匀稳定性 $\beta_n \leq 2L^2/((\lambda - \kappa)n)$ 。相关损失可积时，对任意固定 $\mathbf{w} \in \mathcal{W}$ 还有

$$\mathbb{E}_S R_{\mathcal{P}}(A_\lambda(S)) - R_{\mathcal{P}}(\mathbf{w}) \leq \frac{2L^2}{(\lambda - \kappa)n} + \frac{\lambda}{2} \|\mathbf{w}\|_2^2.$$

证明. 正则化目标可以写成一个凸函数与 $(\lambda - \kappa)\|\mathbf{w}\|_2^2/2$ 之和，因而为 $(\lambda - \kappa)$ -强凸。对相邻样本的两个最优解，重复定理 7.42 的相加抵消论证，即得稳定性界。由正则化目标的最优性，经验风险相对于固定比较参数的差不超过 $\lambda\|\mathbf{w}\|_2^2/2$ 。再加上期望泛化差就得到第二式。■

当 $\kappa = 0$ 时，这恢复凸正则化的结论。但若 $\kappa > 0$ 固定，条件 $\lambda > \kappa$ 阻止正则化系数趋于零，第二项也就不能在整个比较空间上自动趋于零。因此，该定理证明了足够强的正则化能提高稳定性，尚未证明原非凸问题的 PAC 可学习性。若只求某个局部极小值，前面的全局最优性比较也不能直接使用。

7.5.3 非凸学习问题的随机梯度下降

正则化通过改变目标函数的曲率获得稳定性；对于仍然保持非凸的目标，也可以直接比较 SGD 在相邻样本上的两条迭代轨迹。与凸情形不同，同一个观测对应的梯度更新可能放大已经产生的参数差距。因此，每一步引入的扰动以及它在后续迭代中被放大的程度，都需要计入稳定性上界。这使学习率和训练轮数成为控制期望泛化差的关键因素。

定理 7.49 非凸 SGD 的扰动传播 设每个损失在欧氏空间上可微、 L -Lipschitz 且 M -光滑， $M > 0$ 。采用式 (7.19)，从相同的确定初值出发，索引独立均匀抽取，步长 $\eta_t \geq 0$ 。则最后一步输出对内部随机性

平均后的均匀稳定性满足

$$\beta_{n,T} \leq \frac{2L^2}{n} \sum_{t=0}^{T-1} \eta_t \prod_{j=t+1}^{T-1} (1 + M\eta_j).$$

其中空乘积取 1。相关损失可积时，右侧也控制期望泛化差的绝对值。

证明. 在相邻样本上使用相同随机索引，记两次迭代参数的平均距离为 D_t 。未抽中替换位置时，光滑性给出放大因子 $1 + M\eta_t$ 。抽中时，在同一观测的更新之外，再加入两个观测的梯度差；梯度范数均不超过 L ，所以新增距离至多 $2L\eta_t$ 。由抽中概率 $1/n$ ，

$$D_{t+1} \leq (1 + M\eta_t)D_t + \frac{2L\eta_t}{n}, \quad D_0 = 0.$$

逐步展开递推式，每一步产生的扰动都乘以后续更新的放大因子。最后用 Lipschitz 性将 D_T 乘以 L ，即得损失差上界。■

固定步长 $\eta > 0$ 时，这个几何级数给出

$$\beta_{n,T} \leq \frac{2L^2}{Mn} ((1 + M\eta)^T - 1).$$

它是最坏情形上界，不能据此断定每个非凸算法的实际泛化差都指数增长。但它说明只知道光滑性还不足以支持任意长时间训练；减小步长、限制训练轮数，或利用轨迹经过区域的更好曲率条件，都会影响能证明的保证。

SGD 还有一项可以利用的性质：在第一次抽中被替换的观测之前，两次运行完全相同。若此时步长已经减小，后续扰动的放大就弱于从第一步开始估计。下面给出 Hardt、Recht 与 Singer 分析思路的一种常数较宽松的形式¹²。

定理 7.50 递减步长的非凸 SGD 泛化界 在定理 7.49 的条件下，进一步设 $0 \leq \ell \leq 1$ ，且 $\eta_t \leq c/(t+1)$ ，其中 $c > 0$ 。记 $a = Mc$ 。对任意整数 $1 \leq t_0 \leq T$ ，有

$$\beta_{n,T} \leq \frac{t_0}{n} + \frac{2L^2}{Mn} \left(\frac{T}{t_0} \right)^a.$$

特别地，取 $t_0 = \lceil T^{a/(a+1)} \rceil$ ，可得

$$\beta_{n,T} \leq \frac{1 + (1 + 2L^2/M)T^{a/(a+1)}}{n}.$$

证明. 前 t_0 次抽样中至少一次选中替换位置的概率不超过 t_0/n 。在这一事

¹² M. Hardt, B. Recht, Y. Singer, *Train Faster, Generalize Better: Stability of Stochastic Gradient Descent* In Proceedings of the 33rd International Conference on Machine Learning, 2016, pp. 1225–1234

件上用损失差至多 1 估计。在其补事件上，两条轨迹在时刻 t_0 完全相同，后续索引仍独立均匀，因而可从 $D_{t_0} = 0$ 开始使用前一定理的递推式。利用 $1 + u \leq e^u$ 及调和和的积分上界，有

$$\prod_{j=t+1}^{T-1} \left(1 + \frac{a}{j+1}\right) \leq \left(\frac{T}{t+1}\right)^a.$$

所以后续的条件期望损失差至多为

$$\frac{2cL^2T^a}{n} \sum_{t=t_0}^{T-1} (t+1)^{-a-1} \leq \frac{2cL^2T^a}{an} t_0^{-a}.$$

这里使用 $\sum_{t=t_0}^{T-1} (t+1)^{-a-1} \leq \int_{t_0}^T x^{-a-1} dx \leq t_0^{-a}/a$ 。合并两种事件，并代入 $a = Mc$ 得到第一式。再代入所给 t_0 ，利用 $T^{a/(a+1)} \leq t_0 \leq T^{a/(a+1)} + 1$ 即得第二式。■

固定 L, M, c ，取 $T = n$ 时，该界按 $n^{-1/(a+1)}$ 的量级趋于零。更一般地，若 T 按 n^p 增长，只要 $p < (a+1)/a$ ，稳定性上界仍趋于零。这允许一定程度的重复访问样本，但结论控制的是期望泛化差。要得到相对于最优期望风险的学习保证，还必须有相应的经验优化误差 $\rho_{n,T} \rightarrow 0$ 。仅仅满足步长与轮数条件，不能保证算法已找到好的经验解。

非凸问题要从“小泛化差”走到“接近最优期望风险”，必须加入能够控制经验优化误差的结构。一个有用条件是 Polyak–Łojasiewicz 条件，简称 PL 条件：经验风险尚高于最优值时，梯度范数也必须足够大。它排除了损失仍很高却梯度已经为零的点，但不要求函数凸。

定义 7.51 PL 条件 设 F 可微且 $F_* = \inf_{\mathbf{w} \in \mathcal{W}} F(\mathbf{w}) > -\infty$ 。给定 $\mu > 0$ ，若对指定区域内的所有 $\mathbf{w}$ 都有

$$\frac{1}{2} \|\nabla F(\mathbf{w})\|_2^2 \geq \mu(F(\mathbf{w}) - F_*),$$

则称 F 在该区域内相对于 F_* 满足参数为 μ 的 PL 条件。

对 $F(w) = w^2/2$ ，两侧在 $\mu = 1$ 时相等；而前面的 $(w^2 - 1)^2$ 在 $w = 0$ 处不满足 PL 条件，因为左侧为零，右侧却为正。PL 条件也允许非凸函数，例如文献中的 $w^2 + 3 \sin^2 w$ 满足某个正参数的全局 PL 条件，但其二阶导数在部分位置为负¹³。因此 PL 条件控制的是梯度与最优值差距的关系，而非所有方向的曲率。

对于随机梯度下降，即使经验梯度满足 PL 条件，单次使用的随机梯度仍可能偏离经验梯度。因此，学习保证还要保留随机梯度的方差项。下面将这一项与稳定性和初始优化误差一起列出。

¹³ H. Karimi, J. Nutini, M. Schmidt, *Linear Convergence of Gradient and Proximal-Gradient Methods Under the Polyak–Łojasiewicz Condition* In arXiv preprint arXiv:1608.04636, 2016

定理 7.52 PL 条件下非凸 SGD 的学习保证 对每份样本运行 SGD, 初值固定, 索引 i_t 独立均匀取自 $\{1, \dots, n\}$, 步长 $0 < \eta \leq 1/M$ 。假设所有样本和索引序列的迭代点均留在同一凸区域 $\mathcal{W}$ 内; 各单样本损失在该区域的邻域内可微、 M -光滑, 且区域内梯度范数不超过 L 。每个经验风险在迭代点满足参数 $0 < \mu \leq M$ 的 PL 条件, 比较值为 $\inf_{\mathbf{w} \in \mathcal{W}} \hat{R}_S(\mathbf{w})$, 初始经验优化误差至多为 D 。进一步设对所有 S 和 $\mathbf{w} \in \mathcal{W}$ 有

$$\frac{1}{n} \sum_{i=1}^n \|\nabla \ell(\mathbf{w}, z_i) - \nabla \hat{R}_S(\mathbf{w})\|_2^2 \leq \nu^2.$$

若相关损失可积, 则

$$\begin{aligned} \mathbb{E}_{S,U} R_{\mathcal{P}}(\mathbf{w}^{(T)}) - \inf_{\mathbf{w} \in \mathcal{W}} R_{\mathcal{P}}(\mathbf{w}) \\ \leq \frac{2L^2}{Mn} ((1 + M\eta)^T - 1) + D(1 - \mu\eta)^T + \frac{M\eta\nu^2}{2\mu}. \end{aligned}$$

证明. 定理 7.49 的轨迹比较给出第一项均匀稳定性上界。为分析经验优化误差, 固定样本及此前的迭代结果, 记 $\mathbf{g}_t = \nabla \ell(\mathbf{w}^{(t)}, z_{i_t})$ 。条件均值满足 $\mathbb{E} \mathbf{g}_t = \nabla \hat{R}_S(\mathbf{w}^{(t)})$, 条件二阶矩满足

$$\mathbb{E} \|\mathbf{g}_t\|_2^2 \leq \|\nabla \hat{R}_S(\mathbf{w}^{(t)})\|_2^2 + \nu^2.$$

将更新代入光滑性不等式, 并对当前索引取期望, 得到

$$\mathbb{E} \hat{R}_S(\mathbf{w}^{(t+1)}) \leq \hat{R}_S(\mathbf{w}^{(t)}) - \frac{\eta}{2} \|\nabla \hat{R}_S(\mathbf{w}^{(t)})\|_2^2 + \frac{M\eta^2\nu^2}{2}.$$

这里使用 $\eta \leq 1/M$ 。由 PL 条件, 平均经验优化误差 e_t 满足

$$e_{t+1} \leq (1 - \mu\eta)e_t + \frac{M\eta^2\nu^2}{2}, \quad e_0 \leq D.$$

求和几何级数, 得到 $e_T \leq D(1 - \mu\eta)^T + M\eta\nu^2/(2\mu)$ 。再加上稳定性控制的期望泛化差, 即得结论。 ■

三项分别来自样本替换、初始优化误差以及随机梯度波动。固定非零步长时, 最后一项不随训练轮数消失; 延长训练也可能增大稳定性项。若用全梯度替代随机梯度, 方差项为零, 并恢复全梯度下降的相应学习保证。

当 L, M, μ, D, ν 都不随分布和样本量改变时, 可以让步长随样本量减小, 同时缓慢增加总步长。具体取 $\eta_n = n^{-r}$, 其中 $r > 0$, 并令 $T_n = \lfloor c_0 \log n / \eta_n \rfloor$, 其中 $0 < c_0 < 1/M$; 充分大的 n 满足步长约束。此时三项分别不超过 $O(n^{Mc_0-1})$ 、 $O(n^{-\mu c_0})$ 和 $O(n^{-r})$, 因而都趋于零, 得到分布无关 PAC 保证。这说明非凸性并不自动排除可学习, 但统一 PL 条件、迭代区域和梯度条

件都须针对问题证明，不能仅凭训练曲线下降就视为成立。

7.6 本章小结

超出零一分类后，本章给出的可学习性保证不再依赖单一容量判据。一致收敛控制整个损失函数空间，算法稳定性控制算法实际输出；二者都要与经验优化误差结合，才能推出较低的超额期望风险。这些结论的适用对象由观测空间、决策集合、损失函数和允许分布族共同确定。把分类正确与否扩展为实数损失后，有限输入上的预测数目不再足以描述复杂度，还需区分函数值相差的尺度。伪维延续了阈值比较的思想，胖打散维进一步要求预测与阈值之间保留指定间隔。在本章列明的有界性与可测性条件下，若允许观测空间上的全部分布，各正尺度上的有限胖打散维刻画一致收敛；对于受限分布族，它仍提供充分条件，但不再自动成为必要条件。

一致收敛约束整个损失函数空间，稳定性则分析算法实际输出对训练样本变化的反应。本章的一般学习基本定理把可学习性与存在适当的稳定、渐近经验风险最小化算法联系起来，其中“存在”与经验优化要求都不能省略。一个始终输出同一决策的算法可以完全稳定，却不一定学到期望风险较低的决策；也不能要求任意成功算法都满足每一种稳定性定义。

不同稳定性给出的信息各有范围。留一法稳定性比较删去一个观测前后的损失；平均稳定性直接联系期望泛化差；均匀稳定性还可借助集中不等式给出高概率保证。参数稳定性需经过损失的 Lipschitz 条件才能转成损失稳定性，互信息与条件互信息则从算法输出保留了多少样本信息出发控制期望泛化差。由平均保证得到 PAC 结论时，还需经验优化误差一同趋于零，且速率不能依赖具体分布。

正则化、步长和停止时刻使这些抽象条件成为可以分析的算法选择。凸性与曲率能够限制样本扰动的传播；非凸问题也能得到有条件的保证，但必须核对光滑性、迭代区域以及相应的优化条件。下一章将这些分析用于神经网络，讨论参数大小、梯度特征、更新轨迹和参数分布怎样进入期望风险上界，而不是把参数数量直接等同于算法的实际泛化能力。

延伸阅读 Shalev-Shwartz 等关于可学习性、稳定性与一致收敛的论文，是理解本章一般学习基本定理的主要入口。阅读时应特别区分不同的渐近经验最优性要求，以及定理陈述的是某类算法的充分性，还是存在某个算法的必要性¹⁴。

Bousquet 与 Elisseeff 系统研究了稳定性如何产生期望风险保证；Hardt、Recht 与 Singer 则把这一思路用于随机梯度下降。前者适合补充不同稳定性定义与集中分析，后者适合对照凸与非凸情况下样本扰动递推为何不同¹⁵。

¹⁴ S. Shalev-Shwartz, O. Shamir, N. Srebro, K. Sridharan, *Learnability, Stability and Uniform Convergence* In Journal of Machine Learning Research, 2010, vol. 11, no. 90, pp. 2635–2670

¹⁵ O. Bousquet, A. Elisseeff, *Stability and Generalization* In Journal of Machine Learning Research, 2002, vol. 2, pp. 499–526; M. Hardt, B. Recht, Y. Singer, *Train Faster, Generalize Better: Stability of Stochastic Gradient Descent* In Proceedings of the 33rd International Conference

若希望从算法对样本的依赖继续延伸，可阅读 Steinke 与 Zakynthinou 的条件互信息分析。它把学习、压缩与信息量放进同一个框架；阅读时可对照本章的双样本构造，明确互信息究竟比较哪些随机变量，以及为何普通互信息与条件互信息不能直接互换¹⁶。。

¹⁶ T. Steinke, L. Zakynthinou, *Reasoning About Generalization via Conditional Mutual Information* In Proceedings of the Thirty Third Conference on Learning Theory, 2020, pp. 3437–3452

深度学习的可学习性

一个网络已经把样本中的邮件全部分对，继续增加参数以后，它在新邮件上的错误率却还可能下降。这并不符合一种常见直觉：模型越复杂，越容易记住样本，也就越容易过拟合。困难在于，“能够记住样本”只描述网络的表达能力，并没有说明训练算法最终选择了什么假设。同一个网络架构既可以表示有用的分类函数，也可以表示只记住样本的函数。

VC 维和一致收敛考察整个假设空间，算法稳定性则考察训练结果对样本变化的敏感程度；稳定性还需与经验最优性结合，才能得到可学习性保证。本章考察这些工具怎样进入神经网络分析：权重范数怎样限制函数复杂度，训练过程怎样选择解，以及样本变化怎样传递到参数、预测和损失。能够直接处理非线性网络时，正文明确给出架构、范数或训练条件；需要说明选解机制时，则使用线性回归、线性分类和深层线性网络等可解模型，并保留结论不能直接推广到一般非线性网络的边界。

本章据此沿四个入口追踪训练选择。参数大小从所选函数的复杂度入手，初始参数梯度则在相应宽度和训练条件下把问题转到近似固定的特征空间。若训练显著改变特征，参数更新需要解释算法的隐式选解。参数分布进一步提供两种描述，分别面向神经元群体与完整网络随机预测器。每个入口都必须通过具体的复杂度、稳定性或期望风险推导接到学习保证，并保留网络表示目标关系的能力。缩放与顿悟等现象还会改变模型规模或训练程度，本章只讨论它们怎样暴露现有分析的边界，不把跨任务、长度外推和推理过程并入同一个学习问题。

8.1 神经网络的学习问题

8.1.1 网络与学习目标

前馈网络通过逐层变换把输入转换成预测分数。每一层先用权重矩阵组合上一层的数值，再用激活函数逐坐标变换结果。例如，ReLU 函数 $\phi(a) = \max\{0, a\}$ 保留正数、把负数置零，使多层模型不再等价于一个线性变换。

暂时省略偏置项， L 层网络写为

$$f_{\mathbf{W}}(\mathbf{x}) = \mathbf{W}_L \phi(\mathbf{W}_{L-1} \phi(\cdots \phi(\mathbf{W}_1 \mathbf{x}) \cdots)), \quad (8.1)$$

其中 $\mathbf{W}_\ell \in \mathbb{R}^{d_\ell \times d_{\ell-1}}$ ， d_0 是输入维度。把全部可训练参数排列成向量 $\boldsymbol{\theta} \in \mathbb{R}^p$ ，也可将网络记为 $f_{\boldsymbol{\theta}}$ 。参数量 p 说明需要存储多少个可调数值，深度 L 说明输入依次经过多少层变换。它们都不直接等于假设空间的 VC 维。

给定独立同分布样本 $S = (z_1, \dots, z_n) \sim \mathcal{P}^n$ ，其中 $z_i = (\mathbf{x}_i, y_i)$ ，学习算法通过减小经验风险选择参数：

$$\hat{R}_S(\boldsymbol{\theta}) = \frac{1}{n} \sum_{i=1}^n \ell(f_{\boldsymbol{\theta}}(\mathbf{x}_i), y_i), \quad R_{\mathcal{P}}(\boldsymbol{\theta}) = \mathbb{E}_{(\mathbf{x}, y) \sim \mathcal{P}} \ell(f_{\boldsymbol{\theta}}(\mathbf{x}), y).$$

经验风险由已有样本计算，期望风险描述同一数据分布下的新样本表现。本章在分布已明确时简写为 $R(\boldsymbol{\theta})$ 。损失函数会随问题变化，涉及分类错误率时明确使用零一损失；涉及梯度下降的精确推导时则说明所用的平方损失或逻辑损失。

若存在参数使给定样本的经验风险为零，就称该模型能够在这份样本上**插值**（interpolation）。平方损失下，插值要求每个预测数值都等于标签；零一损失下，插值只要求每个类别预测正确。交叉熵则通常只能在分数不断增大时趋近零，不能把“分类全部正确”与“交叉熵已经等于零”混为一谈。**过参数化**（overparameterization）通常表示参数相对于样本或拟合约束十分充足； $p > n$ 是常用的粗略指标，但能否插值还取决于架构、数据和损失。

8.1.2 VC 维与样本量

早期研究把神经网络看作一个由架构限定的假设空间，再使用 VC 维分析所需样本量。Baum 与 Haussler 在 1988 年的工作中研究了网络规模与泛化所需样本数的关系，重点对象包括阈值网络¹。这条途径继承了二分类理论：只要能控制架构所表示的分类假设的 VC 维，就能得到分布无关的统计学习保证，而不必先解释训练算法的每一步更新。

网络的 VC 维不仅取决于参数量，也取决于计算结构。对于分段线性网络，Bartlett 等给出了接近紧致的结果：以 p 表示参数量、 L 表示层数，ReLU 网络的 VC 维具有 $O(pL \log p)$ 量级的上界，并存在达到 $\Omega(pL \log(p/L))$ 量级的架构，其中下界在相应的参数范围内成立²。这里的下界是对某些架构的存在性结论，并不意味着每个具有 p 个参数的网络都达到该容量。

将这种容量估计代入二分类学习基本定理，就得到网络的统计可学习性结论。下面把网络结构的分析与学习保证的推导分开，以免把“存在一个学习算法”误读为“梯度下降一定能够找到所需参数”。

¹ E. B. Baum, D. Haussler, *What Size Net Gives Valid Generalization?* In *Advances in Neural Information Processing Systems*, 1988

² P. L. Bartlett, N. Harvey, C. Liaw, A. Mehrabian, *Nearly-tight VC-dimension and Pseudodimension Bounds for Piecewise Linear Neural Networks* In *Journal of Machine Learning Research*, 2019, vol. 20, no. 63, pp. 1–17

定理 8.1 有限 VC 维网络的不可知 PAC 样本量保证 设固定架构所表示的二分类假设空间为 $\mathcal{H}$, 其 VC 维为有限数 $d \geq 1$, 并满足前述可测性条件。对于零一损失, 存在通用常数 $c > 0$, 使得任意 $\varepsilon, \delta \in (0, 1)$ 和任意分布 $\mathcal{P}$ 下, 只要

$$n \geq c \frac{d \log(2/\varepsilon) + \log(2/\delta)}{\varepsilon^2},$$

每个经验风险最小化算法输出的 $\hat{h}$ 都以至少 $1 - \delta$ 的概率满足

$$R_{\mathcal{P}}(\hat{h}) \leq \inf_{h \in \mathcal{H}} R_{\mathcal{P}}(h) + \varepsilon.$$

证明. 由有限 VC 维的一致收敛结论, 在所给样本量下, 可以使事件 $\sup_{h \in \mathcal{H}} |\hat{R}_S(h) - R_{\mathcal{P}}(h)| \leq \varepsilon/2$ 以至少 $1 - \delta$ 的概率成立。在该事件上, 对任意 $h \in \mathcal{H}$ 有

$$R_{\mathcal{P}}(\hat{h}) \leq \hat{R}_S(\hat{h}) + \frac{\varepsilon}{2} \leq \hat{R}_S(h) + \frac{\varepsilon}{2} \leq R_{\mathcal{P}}(h) + \varepsilon.$$

对右侧的 h 取下确界即可。证明使用了 ERM 的经验风险比较性质, 没有给出实现 ERM 的计算方法。 ■

因此, 固定有限架构的统计可学习性并不是一个悬而未决的问题。实际困难常发生在另一个尺度: 当前只有 n 个样本, 而网络容量给出的充分样本量远大于 n 。此时定理仍然正确, 却可能只能给出大于 1 的零一损失下的期望风险上界, 无法解释已经观察到的低错误率。若算法只找到近似 ERM, 还需把经验风险的优化误差加入上界。

8.1.3 过参数化的挑战

现代深度学习把这个差距表现得十分突出。Zhang 等关于随机标签的实验显示, 一些深度网络既能拟合真实标签, 也能拟合随机打乱的标签³。拟合随机标签说明架构的表达力很强, 但两种训练结果的期望风险可以相差很大。容量理论考察假设空间允许的最坏情形, 不能单凭架构容量区分这两种结果。图 8.1 把这三个对象画在同一张图中: 外层区域是架构能够表示的全部假设, 内层区域是把当前样本全部拟合正确的假设, 实心点是算法最终选出的一个假设。泛化分析需要解释这个点在新输入上的表现, 不能只观察外层区域有多大。

图中的内层区域可能同时包含两种完全不同的分类假设。一种只记住已经出现的邮件, 遇到新邮件便采用任意默认分类; 另一种利用促销词、链接等特征之间的关系预测类别。采用零一损失时, 它们在当前样本上的经验风险都可以为零, 后者却可能在新邮件上继续有效。增加参数以后,

³ C. Zhang, S. Bengio, M. Hardt, B. Recht, O. Vinyals, *Understanding Deep Learning (Still) Requires Rethinking Generalization* In Communications of the ACM, 2021, vol. 64, no. 3, pp. 107–115




图 8.1 架构、样本和算法分别限定不同对象。外层是假设空间，内层是当前样本上经验风险为零的插值解集合；虚线表示样本施加的约束，实线表示算法的输入与输出。初始化、优化器和正则化参与选解。强调点仅示意算法选出一个插值解，不保证任意算法都实现插值；集合的形状和大小没有数值含义，插值也不保证期望风险小。

这两种假设都可能更容易被表示出来，所以“能拟合样本的解更多”本身并不能决定期望风险上升还是下降。

图中的箭头强调了算法的选择作用。即使架构和样本保持不变，初始化、步长、优化器或正则化改变，也可能把算法带向不同的插值解。要解释实际网络的泛化，就需要寻找比“这个网络有多少参数”更细的依据：哪些解具有较小的有效复杂度，训练又为什么偏向它们。这也是后面分别研究参数大小、训练轨迹与参数分布的共同起点。

过参数化也不必然导致更严重的过拟合。某些模型的期望风险在接近插值阈值时上升，越过该阈值后反而下降，形成**双重下降** (double descent) 曲线⁴。图 8.2 给出这种形态的定性示意。接近插值阈值时，拟合标签中的噪声可能需要很敏感的解；参数进一步增加后，可供选择的插值解更多，算法可能找到范数较小或对扰动较不敏感的解。第二次下降依赖数据分布和选解方式，不能推成“增加参数总能降低期望风险”。

阅读图 8.2 时，需要分别观察经验风险与期望风险。虚线到达零附近，表示模型已经能够拟合当前样本，并没有说明样本之外的预测也正确。实线在插值阈值附近的峰值，表示某些选解方式此时对数据扰动十分敏感；右侧的下降则说明，继续增加参数以后，算法有可能选择更适合预测新输入的插值解。这三种现象的区别，正是单独观察经验风险无法解释的部分。

例如，欠定线性回归可以有无穷多个插值解。从零初始化出发的梯度下降选择其中的最小欧氏范数解，而不会等概率地选择任意一个解。增加参

⁴ M. Belkin, D. Hsu, S. Ma, S. Mandal, *Reconciling Modern Machine-Learning Practice and the Classical Bias-Variance Trade-Off* In Proceedings of the National Academy of Sciences, 2019, vol. 116, no. 32, pp. 15849–15854

数可以改变这个最小范数解及其对噪声的响应，也就可能改变期望风险。第8.4节将完整证明这种选解现象；这里先保留一个结论：过参数化的作用必须连同算法一起分析。




图 8.2 双重下降的定性示意。虚线表示经验风险，实线表示一种可能出现的期望风险变化。插值后的期望风险还取决于算法如何选择。图中曲线用于说明概念，不是实验数据，也不表示所有网络都出现第二次下降。

这些现象要求理论进一步说明算法选择了什么。范数界限制所选函数的大小与变化幅度；初始参数梯度通过神经切线核确定近似固定的特征空间；梯度更新的动力学决定算法偏好的解；参数分布则描述神经元群体的演化或训练结果附近的一组网络。这些研究在时间上相互交叠，后来的方法也继续使用早期的复杂度与稳定性工具。

8.1.4 从一般学习理论到神经网络

这些解释最终都要回答同一个问题：网络在样本上的损失较低时，怎样保证新样本上的期望损失也低。所需分析可统一写成期望泛化差与经验优化误差的组合。对于输出属于比较空间 $\mathcal{H}$ 的算法 A ，记

$$\begin{aligned}\Delta_n &= \mathbb{E}_S [R(A(S)) - \hat{R}_S(A(S))], \\ \rho_n &= \mathbb{E}_S \left[\hat{R}_S(A(S)) - \inf_{h \in \mathcal{H}} \hat{R}_S(h) \right].\end{aligned}$$

在相关期望存在时，有

$$\mathbb{E}_S R(A(S)) - \inf_{h \in \mathcal{H}} R(h) \leq \Delta_n + \rho_n. \quad (8.2)$$

因为对于每个固定 h 都有 $\mathbb{E}_S \hat{R}_S(h) = R(h)$ ，所以 $\mathbb{E}_S \inf_h \hat{R}_S(h) \leq \inf_h R(h)$ ，代入便得到该式。其中 Δ_n 是期望泛化差， ρ_n 表示算法距离经验最优还有

多远；两者同时受控，才能获得相对于 $\mathcal{H}$ 的低超额期望风险。训练只降低经验风险，未必同时减小 Δ_n 。

前章的一致收敛和算法稳定性给出了控制 Δ_n 的两条途径。前者同时控制一个函数空间中所有假设的经验风险与期望风险之差，后者利用算法实际输出对样本变化的反应。二者考察的关系不同：VC 维研究固定输入上的不同预测，稳定性研究不同训练样本产生的输出。一个网络架构的假设空间不变，训练算法的稳定性却可能随着初始化、正则化和优化方式而改变。

参数大小可以同时参与这两条途径。若预先限制权重范数，可以研究这个受限函数空间的复杂度；若研究样本替换后的参数变化，权重范数又可能控制参数变化被放大为损失变化的程度。后一种推导还需要证明相邻样本产生的参数确实接近，单独限制参数大小并不够。参数分布也要通过分布距离或信息量进入期望风险分析，不能只凭训练结果具有某种分布形式就认定泛化良好。

这些方法仍须遵守前面的不可学习性结论。对于零一损失、任意输入与标签联合分布下的二分类 PAC 学习，无限 VC 维的假设空间不可学习，换用稳定性分析也不能改变这一结论。后文不显含网络宽度的保证，会明确保留范数、分类间隔或数据分布等条件；它们回答的是这些条件下的期望风险问题，并不自动给出整个无限 VC 维分类空间的分布无关 PAC 保证。

以下各节会分别说明所控制的期望风险、样本量的作用和训练算法还需满足的条件。其中，高概率期望风险界、对样本取平均的期望风险界和经验风险下降速度是不同的保证，比较它们时必须保持损失函数与概率含义一致。

8.2 基于参数大小的可学习性

上一节遇到的困难是，同一个大网络既能拟合随机标签，也能学到可推广的关系。按参数数量计算的 VC 维需要同时覆盖这两种行为，因此可能给出过大的样本量要求。如果训练实际选出的假设只使用了假设空间中较受约束的一部分，就有理由改用这部分假设的复杂度来估计期望风险。权重范数提供了一种可以计算的约束方式。

这里的“参数大小”指权重向量或矩阵的范数，不是参数个数。直观上，模型为了分别迁就每个样本的偶然波动，可能需要很强的局部变化；限制权重共同产生的放大能力，可以减少这类变化。上一章的正则化也控制参数大小，但本节先从假设空间的复杂度出发，考察给定范数范围内所有网络的经验风险与期望风险之间的关系，暂不要求解释参数是怎样训练出来的。

这种做法可以使泛化界不直接依赖网络宽度，却带来了新的问题。多层

网络中不同范数怎样组合，参数缩放会不会改变结论，分类间隔又应怎样计入，都需要重新说明。即使这些问题解决了，较小的范数界也只评价所得假设，不会自动保证梯度下降找到它。因此，本节先建立参数大小与期望风险的联系，后面的理论再讨论训练过程如何产生这样的解。

8.2.1 权重大小与分类间隔

参数量相同的两个网络，可以对输入变化表现出完全不同的敏感程度。在线性预测中， $|\langle \mathbf{w}, \mathbf{x} - \mathbf{x}' \rangle| \leq \|\mathbf{w}\|_2 \|\mathbf{x} - \mathbf{x}'\|_2$ ，权重范数直接控制输入扰动被放大的程度。网络范数界沿着这一思路，把约束从“允许多少个参数”转向“这些参数共同表示多大的函数”。Bartlett 在 1996 年的研究中已经系统提出，适当条件下，权重大小可以比网络规模更直接地决定泛化保证⁵。

分类还需要考虑预测分数离决策边界有多远。真实类别为第一类时，分数 (3, 2, 0) 和 (2.01, 2, 0) 都给出正确分类，但前者领先第二名 1 分，后者只领先 0.01 分。后一种预测更容易被小扰动改变。这种领先幅度称为分类间隔。

⁵ P. L. Bartlett, *For Valid Generalization the Size of the Weights is More Important than the Size of the Network* In *Advances in Neural Information Processing Systems*, 1996

定义 8.2 分类间隔 设 $f_{\mathbf{w}} : X \rightarrow \mathbb{R}^K$ 是分类分数函数。其在带标签输入 $(\mathbf{x}, y)$ 处的分类间隔定义为

$$\text{margin}_{\mathbf{w}}(\mathbf{x}, y) = f_{\mathbf{w}}(\mathbf{x})_y - \max_{j \neq y} f_{\mathbf{w}}(\mathbf{x})_j. \quad (8.3)$$

对于取值为 $\{-1, +1\}$ 的二分类标签和标量分数 $f(\mathbf{x})$ ，定义间隔为 $yf(\mathbf{x})$ 。

正间隔表示正确类别的分数更高。若每个类别分数的变化不超过 α ，多分类间隔的变化不超过 2α ，所以原间隔大于 2α 时预测仍然正确。范数与间隔需要一起使用：只把输出分数放大，既增大权重范数也增大间隔，并没有改变分类函数或实际错误率。

8.2.2 不显含宽度的期望风险界

两层 ReLU 网络可以说明范数约束怎样替代直接的参数计数。隐藏层越宽，可用的特征越多；如果输出权重的绝对值之和固定，网络就不能同时无限放大所有特征。下面允许隐藏单元数任意大，但要求这一总量受到控制。

定理 8.3 两层网络的范数与期望风险 在抽样前固定 $A, B, r, \gamma > 0$ 。

设 $\|\mathbf{x}\|_2 \leq r$, 并令

$$\mathcal{F}_{A,B} = \left\{ \mathbf{x} \mapsto \sum_{j=1}^m a_j \phi(\mathbf{w}_j^\top \mathbf{x}) : m \in \mathbb{N}, \sum_{j=1}^m |a_j| \leq A, \|\mathbf{w}_j\|_2 \leq B \right\},$$

其中 ϕ 为 ReLU 函数。则任意输入样本上的经验 Rademacher 复杂度满足

$$\hat{\mathfrak{R}}_S(\mathcal{F}_{A,B}) \leq \frac{2ABr}{\sqrt{n}}.$$

对于独立同分布的二分类样本, 标签取 $\{-1, +1\}$, 以至少 $1 - \delta$ 的概率, 所有 $f \in \mathcal{F}_{A,B}$ 同时满足

$$\mathbb{P}_{(\mathbf{x}, y) \sim \mathcal{D}}\{yf(\mathbf{x}) \leq 0\} \leq \frac{1}{n} \sum_{i=1}^n \mathbb{I}\{y_i f(\mathbf{x}_i) \leq \gamma\} + \frac{4ABr}{\gamma\sqrt{n}} + 3\sqrt{\frac{\log(2/\delta)}{2n}}. \quad (8.4)$$

这里把零间隔也计为错误, 因此左侧同时控制采用任意固定平局规则时的零一损失期望风险。

证明. 固定独立随机符号 $\sigma_i \in \{-1, +1\}$ 。输出权重的约束给出

$$\sup_{f \in \mathcal{F}_{A,B}} \sum_{i=1}^n \sigma_i f(\mathbf{x}_i) = A \sup_{\|\mathbf{w}\|_2 \leq B} \left| \sum_{i=1}^n \sigma_i \phi(\mathbf{w}^\top \mathbf{x}_i) \right|.$$

绝对值可分别用正号与负号的上确界之和控制; 由于 $\mathbf{w} = \mathbf{0}$ 可取, 这两个上确界都非负。随机符号的对称性使它们的期望相同。再用 ReLU 的 1-Lipschitz 性质与收缩不等式, 得到

$$\begin{aligned} \hat{\mathfrak{R}}_S(\mathcal{F}_{A,B}) &\leq \frac{2AB}{n} \mathbb{E}_\sigma \left\| \sum_{i=1}^n \sigma_i \mathbf{x}_i \right\|_2 \\ &\leq \frac{2AB}{n} \sqrt{\sum_{i=1}^n \|\mathbf{x}_i\|_2^2} \leq \frac{2ABr}{\sqrt{n}}. \end{aligned}$$

第二步使用 Jensen 不等式, 交叉项因随机符号独立且均值为零而消失。

令斜坡损失 $\psi_\gamma(u)$ 在 $u \leq 0$ 时为 1, 在 $0 < u < \gamma$ 时为 $1 - u/\gamma$, 在 $u \geq \gamma$ 时为 0。它上界零一错误指示函数, 且为 $1/\gamma$ -Lipschitz。固定样本标签后, $\sigma_i y_i$ 仍是独立随机符号, 因此损失函数空间的经验 Rademacher 复杂度不超过 $\hat{\mathfrak{R}}_S(\mathcal{F}_{A,B})/\gamma$ 。应用定理 5.12 的经验复杂度形式, 并用 $\psi_\gamma(y_i f(\mathbf{x}_i)) \leq \mathbb{I}\{y_i f(\mathbf{x}_i) \leq \gamma\}$, 即得所述期望风险上界。■

这个上界没有直接出现隐藏单元数 m 。当 A, B, r 和间隔尺度 γ 保持固定时, 增加宽度并不必然增加保证所需的样本量。但是, 扩大网络后若 A

或 B 也随之增长, 或者多数样本的间隔变得很小, 上界仍然可能失去作用。

因此, “参数大小比参数数量重要” 应理解为一种有条件的复杂度控制方式。它不意味着只限制原始范数, 就能保证任意宽度网络的零一损失 PAC 可学习性。例如, 把一个 ReLU 网络的所有输出权重乘以很小的正数, 分类符号保持不变, 范数和间隔却会一起变小。分类函数的复杂度没有因此消失, 式 (8.4) 中的范数与间隔之比也没有得到改善。该定理直接提供的是固定间隔尺度下的期望风险保证。

这个结论可以直接换算成样本量的充分条件。给定允许的附加误差 $\varepsilon > 0$, 若

$$n \geq \frac{1}{\varepsilon^2} \left(\frac{4ABr}{\gamma} + 3\sqrt{\frac{\log(2/\delta)}{2}} \right)^2, \quad (8.5)$$

则式 (8.4) 中经验间隔错误率之外的两项之和不超过 ε 。因此, 若训练输出还有至多 α 比例的样本未达到间隔 γ , 其零一损失下的期望风险就以至少 $1 - \delta$ 的概率不超过 $\alpha + \varepsilon$ 。样本量条件控制的是从样本表现推断新样本表现时的附加不确定性; 能否把经验间隔错误率降到 α , 仍需训练算法和数据条件支持。

对训练的指导也由这两项共同决定: 降低权重范数、增大正确分类间隔都可能改善上界, 但单独压小权重也可能使更多样本达不到间隔要求。在范数与间隔之比固定时, 把样本量增至四倍, 会把这里的附加误差上界减半。这是充分保证的缩放关系, 并不意味着实际测试错误率一定减半, 更不表示较少样本一定无法学习。

8.2.3 深层网络的谱复杂度

深层网络中, 扰动经过各层时会被连续放大。矩阵的谱范数 $\|\mathbf{W}\|_2$ 表示单位长度向量经过线性变换后的最大长度, 因此各层谱范数的乘积可以控制整体放大倍数。若第 ℓ 个激活函数的 Lipschitz 常数为 a_ℓ , 还需把这些因子相乘。图 8.3 把输入变化沿各层传递的上界放在同一条链上; 本节后面的定理使用 1-Lipschitz 激活, 因此激活因子可以简化为 1。

仅有这个乘积还不够: 同一放大能力可以由许多不同矩阵实现, 复杂度分析还要计算在给定精度下区分这些矩阵所需的数量。

记 $\|\mathbf{A}\|_{2,1} = \sum_j \|\mathbf{A}_{:,j}\|_2$, 即各列欧氏范数之和。对于无偏置、激活为 1-Lipschitz 且在零点为零的网络, Bartlett、Foster 与 Telgarsky 的谱复杂度在参考矩阵取零时写为

$$\mathcal{C}(\mathbf{W}) = \left(\prod_{\ell=1}^L \|\mathbf{W}_\ell\|_2 \right) \left[\sum_{\ell=1}^L \left(\frac{\|\mathbf{W}_\ell^\top\|_{2,1}}{\|\mathbf{W}_\ell\|_2} \right)^{2/3} \right]^{3/2}. \quad (8.6)$$




图 8.3 谱范数与激活函数共同控制输入扰动。第 ℓ 层线性变换至多放大 $s_\ell = \|W_\ell\|_2$ 倍，层间激活再至多放大 a_ℓ 倍；末层为线性输出。右上方两类因子分别连到乘积上界，大括号归并各层作用。当激活均为 1-Lipschitz 时，只剩谱范数乘积；该乘积仍不是完整的泛化复杂度。

这里按各层谱范数非零书写；零矩阵层可另行处理。这个量的用途是替代单纯的参数计数，把各层权重共同形成的复杂度带入期望风险界。为明确它与样本量的关系，下面采用文献中事先固定各层范数上限的版本⁶。

定理 8.4 深层网络的谱复杂度与期望风险 设无偏置网络具有 L 层，所有层的宽度（包括输入和输出维度）不超过 w ，激活函数固定、为 1-Lipschitz 且在零点为零。在抽样前固定 $r, \gamma, s_\ell, b_\ell > 0$ ，并令

$$C_0 = \left(\prod_{\ell=1}^L s_\ell \right) \left[\sum_{\ell=1}^L (b_\ell / s_\ell)^{2/3} \right]^{3/2}.$$

若 $\|x\|_2 \leq r$ ， $S \sim \mathcal{P}^n$ 且 $n \geq 2$ ，则以至少 $1 - \delta$ 的概率，所有满足 $\|W_\ell\|_2 \leq s_\ell$ 、 $\|W_\ell^\top\|_{2,1} \leq b_\ell$ 的网络同时有

$$R^{01}(W) \leq \hat{R}_{S,\gamma}(W) + \frac{8}{n} + \frac{72rC_0 \log(2w) \log n}{\gamma\sqrt{n}} + 3\sqrt{\frac{\log(1/\delta)}{2n}}, \quad (8.7)$$

其中 R^{01} 为零一损失下的期望风险， $\hat{R}_{S,\gamma} = n^{-1} \sum_i \mathbb{I}\{\text{margin}_W(x_i, y_i) \leq \gamma\}$ 为经验间隔错误率，预测使用固定的平局规则。

证明. 采用 Bartlett 等论文附录引理 A.8 的固定范数约束界。该引理的复杂度项为 $72\|X\|_F C_0 \log(2w) \log n / (\gamma n)$ ，其中 X 的各行为输入样本。由

⁶ P. L. Bartlett, D. J. Foster, M. J. Telgarsky, *Spectrally-Normalized Margin Bounds for Neural Networks* In *Advances in Neural Information Processing Systems* 30, 2017

$\|\mathbf{x}_i\|_2 \leq r$ 可得 $\|\mathbf{X}\|_F \leq r\sqrt{n}$, 代入便得到所述形式。这里使用了外部引理中的网络覆盖数估计, 不将该组合估计视为已在本章证明。 ■

上界中的三项附加量, 衡量的是以经验间隔错误率评价零一损失下的期望风险时需要留出的余量。给定 $\varepsilon > 0$, 只要选取 n 使

$$\frac{8}{n} + \frac{72r\mathcal{C}_0 \log(2w) \log n}{\gamma\sqrt{n}} + 3\sqrt{\frac{\log(1/\delta)}{2n}} \leq \varepsilon,$$

就能以至少 $1 - \delta$ 的概率保证 $R^{01}(\mathbf{W}) \leq \hat{R}_{S,\gamma}(\mathbf{W}) + \varepsilon$ 。这给出了可以逐个代入 n 检查的充分样本量条件。忽略对数因子时, 所需样本量的上界具有 $((r\mathcal{C}_0/\gamma)^2 + \log(1/\delta))/\varepsilon^2$ 量级; 深度和宽度的影响仍会通过 $\mathcal{C}_0$ 及对数项进入结论。因此, 本节并未证明样本量与网络结构无关, 而是用权重的实际约束替代了粗略的参数计数。

这个保证提供了具体的比较标准。若两个网络的经验间隔错误率相近、输入尺度和间隔尺度相同, 较小的谱复杂度可以带来较小的期望风险上界。在复杂度项占主导且忽略对数变化时, 将 $\mathcal{C}_0/\gamma$ 减半, 达到同一附加误差所需的充分样本量约可降至四分之一。但较小的上界并不证明实际错误率一定更低; 若上界仍大于 1, 它甚至尚不能给出非平凡分类错误率保证。训练时应同时观察经验间隔分布与复杂度, 不能只最小化谱范数乘积。

上述定理要求范数上限和间隔尺度事先固定。若根据同一份样本选择这些量, 需要像结构风险最小化那样对多组约束同时建立保证, 或使用文献的自适应版本, 并计入额外对数项, 不能把训练后测得的范数直接代入固定约束定理而省略这一步。

该结果把各层矩阵的近似误差传递到输出, 再与分类间隔比较。对于 ReLU 网络, 将一层乘 $c > 0$ 、下一层除以 c 不会改变函数; 上述谱范数乘积和混合范数比值也保持不变。这种不变性避免把同一函数的不同参数表示误认为不同的分类能力。

矩阵的其余奇异值也能提供信息。若奇异值为 $s_1, \dots, s_q$, **Schatten 范数** (Schatten norm) 定义为 $\|\mathbf{A}\|_{S_p} = (\sum_j s_j^p)^{1/p}$, $p \geq 1$; $p = 2$ 对应 Frobenius 范数, $p \rightarrow \infty$ 对应谱范数。**稳定秩** (stable rank) $\|\mathbf{A}\|_F^2 / \|\mathbf{A}\|_2^2$ 衡量平方能量分布在多少个有效方向上。例如, 奇异值为 $(4, 1, 0)$ 时, 矩阵秩为 2, 稳定秩却为 $17/16$, 因为能量主要集中在第一个方向。不同泛化界使用的谱量不同, 不能把稳定秩直接替换进式 (8.6) 的混合范数项。

谱范数还可以接入前章的参数稳定性理论, 但这时要比较的是两次训练得到的网络。假设替换一条样本后, 第 ℓ 层参数变化不超过 $\alpha_{\ell,n}$ 。该变化在后续各层中会继续传播, 因此各层范数决定参数变化最终会造成多大的损失变化。

定理 8.5 分层参数稳定性与期望泛化差 在上述网络和输入条件下, 设确定性算法 A 对任意相邻样本 S, S' 输出 $\mathbf{W} = A(S)$ 、 $\mathbf{W}' = A(S')$, 且各层均满足谱范数上限 s_ℓ , 并有 $\|\mathbf{W}_\ell - \mathbf{W}'_\ell\|_2 \leq \alpha_{\ell,n}$ 。若损失关于网络输出为 G -Lipschitz, 且相关期望有限, 则

$$|\mathbb{E}_S[R(A(S)) - \hat{R}_S(A(S))]| \leq Gr \sum_{\ell=1}^L \alpha_{\ell,n} \prod_{j \neq \ell} s_j.$$

证明. 从 $\mathbf{W}$ 出发, 逐层把权重替换成 $\mathbf{W}'$ 中的对应权重。只替换第 ℓ 层时, 该层输入的范数不超过 $r \prod_{j < \ell} s_j$; 本层产生的变化再经过后续各层, 输出差至多为 $r \alpha_{\ell,n} \prod_{j \neq \ell} s_j$ 。把各次替换的输出差相加, 再乘损失的 Lipschitz 常数, 便得到损失均匀稳定性上界。由定理 7.15 得到期望泛化差结论。■

这给出了参数大小与算法稳定性的准确关系: 范数上限 s_j 控制变化的放大倍数, $\alpha_{\ell,n}$ 控制替换样本实际造成的参数变化, 两者需要同时出现。仅有范数约束只能推出 $\alpha_{\ell,n} \leq 2s_\ell$, 并不能保证泛化差随 n 增大而消失。而且, 该结论评价的是所用 Lipschitz 损失; 零一损失不连续, 仍需通过间隔等条件联系分类错误率。前面的谱复杂度界沿一致收敛途径推导, 这个定理则沿参数稳定性途径推导, 二者利用了相似的网络结构, 但所需假设不同。

8.3 基于参数梯度初始值的可学习性

参数范数界说明某些网络具有较低的函数复杂度, 但还没有解释训练怎样得到这些函数。一个可以严格分析的情形是: 训练明显改变网络输出, 却几乎不改变输出对参数的局部敏感方向。初始化时的参数梯度于是成为一套近似固定的特征, 神经网络训练可以转化为这套特征上的线性学习。

这条分析路线的关键, 是把输入 $\mathbf{x}$ 映射为初始参数梯度 $\boldsymbol{\varphi}_0(\mathbf{x}) = \nabla_{\boldsymbol{\theta}} f_{\boldsymbol{\theta}^{(0)}}(\mathbf{x})$ 。原始输入可以是一幅图像, 而新特征的每个坐标表示: 轻微改变某个初始参数, 会使这幅图像的预测分数改变多少。输入之间的相似性由这些响应方向决定。适当的无限宽极限使这种特征描述在训练过程中保持有效, 从而可以借助经典核方法分析期望风险。

这里需要区分三步: 初始梯度确定可用的特征; 梯度下降在这些特征中选择拟合样本的函数; 函数的再生核空间范数与数据分布共同决定泛化保证。仅仅证明网络能够拟合样本, 或者核矩阵具有正特征值, 都没有完成后两步分析。

8.3.1 初始梯度与特征空间

考虑含 p 个参数的标量输出网络，记 $f_0 = f_{\theta^{(0)}}$ 。在初始化附近，一阶展开给出

$$f_{\theta}(\mathbf{x}) \approx f_0(\mathbf{x}) + \langle \varphi_0(\mathbf{x}), \mathbf{v} \rangle, \quad \mathbf{v} = \theta - \theta^{(0)}. \quad (8.8)$$

图 8.4 用一个可复算的两参数网络观察这一近似。左侧记录实际梯度下降的参数轨迹，中间在同一输入上比较真实输出与初始一阶展开，右侧单独放大它们的差值。这里的切空间属于模型输出或函数空间：参数位移经初始输出梯度映射为函数 $x \mapsto \langle \varphi_0(x), \mathbf{v} \rangle$ ，其几何形状不由参数平面上任意选取的投影决定。




图 8.4 初始化附近的参数轨迹与输出线性化。教学网络为 $f_{(a,b)}(x) = a \tanh(bx)$ ，初值为 $(1, 1)^T$ ；用单个样本 $(x, y) = (1, 0.9)$ 的半平方损失、步长 0.3 执行六次梯度下降，连同初值共七个检查点。中间的真实输出和一阶输出均在左侧同一参数轨迹上计算；三面板绘图区大小相同，参数、输出和绝对余项各用所标坐标范围，不能按纸面高度直接比较数值。右侧余项末次约为 0.00152。近初始化时二者接近，但余项并非零。参数增量经初始雅可比映射到输出/函数空间的切空间；NTK 是初始梯度在不同输入上的内积。此有限网络示例展示近似对象，不证明训练中核恒定或新输入上的误差受控。

训练在线性化模型中调整的是系数 $\mathbf{v}$ ，而输入特征 $\varphi_0(\mathbf{x})$ 保持不变。这里的梯度由网络结构与初始化共同确定，通常不同于网络最后一层的激活，也不是经验风险关于参数的梯度：前者只依赖输入，后者还依赖标签与当前预测误差。

若从 $\mathbf{v} = 0$ 开始对经验风险做梯度下降，每一步增量都是训练输入梯度特征的线性组合，因而整个参数更新位于 $\text{span}\{\varphi_0(\mathbf{x}_1), \dots, \varphi_0(\mathbf{x}_n)\}$ 中。一个新输入不必落在这 n 个特征张成的子空间内；但它与训练特征的内积决定已经学到的更新如何影响它的预测。

定义 8.6 神经切线核 设网络输出对参数可微。参数为 θ 时的神经切线核 (neural tangent kernel, NTK) 为

$$K_{\theta}(\mathbf{x}, \mathbf{x}') = \langle \nabla_{\theta} f_{\theta}(\mathbf{x}), \nabla_{\theta} f_{\theta}(\mathbf{x}') \rangle.$$

记 $K_0 = K_{\theta^{(0)}}$, 其在 n 个训练输入上的核矩阵为 $\mathbf{K}_0$, 其中 $(\mathbf{K}_0)_{i,j} = K_0(\mathbf{x}_i, \mathbf{x}_j)$ 。

这个内积具有直接的训练含义。若仅用第 i 个样本更新, 记当前损失对预测分数的导数为 a_i , 在线性化模型中就有

$$\Delta \mathbf{v} = -\eta a_i \boldsymbol{\varphi}_0(\mathbf{x}_i), \quad \Delta f(\mathbf{x}_j) = -\eta a_i K_0(\mathbf{x}_j, \mathbf{x}_i).$$

如果两个输入的初始梯度相似, 针对其中一个输入的更新也会明显改变另一个输入的预测; 梯度正交时, 这次更新对另一个输入没有影响。核因此描述训练信息在不同输入之间如何传递。

图 8.5 沿一次更新追踪这两个梯度的作用: 训练输入的梯度产生参数增量, 另一输入的梯度通过内积把该增量转换为预测变化。这里比较的是网络输出对参数的梯度, 不是最后一层表示, 也不是整份经验风险的梯度。




图 8.5 初始梯度特征如何传递一次训练更新。在线性化模型中, 样本 i 的梯度特征与损失对预测的导数 a_i 共同确定参数增量 $\Delta \mathbf{v}$; 将同一增量与样本 j 的梯度特征作内积, 得到 $\Delta f(\mathbf{x}_j)$ 。核值 K_0 正是两个初始梯度特征的内积。虚线把两份梯度关联到同一初始化, 特征条仅示意梯度坐标, 不限定参数维数。对真实有限宽网络使用固定特征, 还需控制核变化与线性化误差。

Jacot 等在特定参数化、初始化与宽度极限下证明, 神经切线核能够趋于确定的核, 且在相应训练条件下保持不变⁷。这使网络可以由固定梯度特征上的模型描述, 常称为**惰性训练** (lazy training)。无限宽本身并不唯

⁷ A. Jacot, F. Gabriel, C. Hongler, *Neural Tangent Kernel: Convergence and Generalization in Neural Networks* In *Advances in Neural Information Processing Systems*, 2018

一确定训练极限；改变缩放方式也可以产生特征持续变化的极限。对有限宽网络，还必须控制核变化和线性化误差。ReLU 的微分关系在可微处理解，不可微点须采用相应导数约定。

8.3.2 核矩阵与训练结果

对半平方经验风险，令 $\mathbf{f}(t)$ 为全部训练输入的预测向量， $\mathbf{y}$ 为标签向量。链式法则使真实网络的梯度流满足

$$\dot{\mathbf{f}}(t) = -\frac{1}{n}\mathbf{K}_{\theta(t)}(\mathbf{f}(t) - \mathbf{y}).$$

在固定核模型中，把随时间变化的核矩阵换成 $\mathbf{K}_0$ ，就能逐个特征方向求解训练过程。连续时间梯度流在这里用于清楚呈现机制；离散梯度下降还需相应的步长条件。

定理 8.7 固定 NTK 下的训练收敛 设 $\mathbf{K}_0$ 正定，最小特征值为 $\lambda_{\min} > 0$ 。若 $\dot{\mathbf{f}}(t) = -\mathbf{K}_0(\mathbf{f}(t) - \mathbf{y})/n$ ，则

$$\mathbf{f}(t) - \mathbf{y} = e^{-\mathbf{K}_0 t/n}(\mathbf{f}(0) - \mathbf{y}),$$

并有 $\|\mathbf{f}(t) - \mathbf{y}\|_2 \leq e^{-\lambda_{\min} t/n} \|\mathbf{f}(0) - \mathbf{y}\|_2$ 。

证明. 将 $\mathbf{K}_0$ 正交对角化。特征值 λ_j 对应的残差分量满足

$$\dot{e}_j(t) = -\lambda_j e_j(t)/n, \quad e_j(t) = e^{-\lambda_j t/n} e_j(0).$$

合并各方向即得矩阵指数表达式，再用 $\lambda_j \geq \lambda_{\min}$ 控制欧氏范数。 ■

较大的特征值对应较快学习的方向，较小的特征值对应较慢学习的方向。迭代次数相同，标签落在哪些方向上就会影响经验风险下降的速度。这仍是训练样本上的结论；分析新输入需要知道训练最终选择了哪个函数，以及表示这个函数需要多大的范数。

8.3.3 再生核空间与期望风险

同一个函数可能有多个参数位移表示。只计算某一组参数的欧氏范数，会把不改变预测的冗余方向也算进去。固定核方法改为计算表示该函数所需的最小特征系数范数，从而把参数表示转成函数本身的复杂度。

记 $\mathcal{H}_{K_0}$ 为由 K_0 生成的**再生核希尔伯特空间** (reproducing kernel Hilbert space, RKHS)。在有限维梯度特征下，它包含所有函数 $g(\mathbf{x}) = \langle \mathbf{v}, \boldsymbol{\varphi}_0(\mathbf{x}) \rangle$,

范数定义为

$$\|g\|_{\mathcal{H}_{K_0}} = \inf\{\|\mathbf{v}\|_2 : g(\mathbf{x}) = \langle \mathbf{v}, \boldsymbol{\varphi}_0(\mathbf{x}) \rangle \text{ 对所有 } \mathbf{x} \text{ 成立}\}.$$

对无限维特征，采用相应内积空间的完备化。这个空间具有再生性质：

$$g(\mathbf{x}) = \langle g, K_0(\mathbf{x}, \cdot) \rangle_{\mathcal{H}_{K_0}}.$$

也就是说，在输入 $\mathbf{x}$ 处评价函数，等价于计算它与核函数 $K_0(\mathbf{x}, \cdot)$ 的内积。以下分析控制的是网络相对于初始化的函数变化 $g = f - f_0$ ，不默认 f_0 恒为零。

训练结果与 RKHS 范数的关系可以精确求出。记残余标签 $r_i = y_i - f_0(\mathbf{x}_i)$ 、 $\mathbf{r} = (r_1, \dots, r_n)^\top$ 。从零参数位移开始，固定特征平方损失的梯度流最终选择最小 RKHS 范数的插值函数。

定理 8.8 初始梯度特征的最小范数插值 设 K_0 正定。满足 $g(\mathbf{x}_i) = r_i$ 的最小 RKHS 范数函数为

$$\hat{g}(\mathbf{x}) = \mathbf{k}_0(\mathbf{x})^\top \mathbf{K}_0^{-1} \mathbf{r}, \quad \mathbf{k}_0(\mathbf{x}) = (K_0(\mathbf{x}_i, \mathbf{x}))_{i=1}^n.$$

其范数满足

$$\|\hat{g}\|_{\mathcal{H}_{K_0}}^2 = \mathbf{r}^\top \mathbf{K}_0^{-1} \mathbf{r} = \sum_{j=1}^n \frac{(\mathbf{u}_j^\top \mathbf{r})^2}{\lambda_j}, \quad (8.9)$$

其中 $(\lambda_j, \mathbf{u}_j)$ 为 $\mathbf{K}_0$ 的正交特征对。该函数也是固定特征平方损失从零位移出发的梯度流极限。

证明. 将任意 g 分解为 $\text{span}\{K_0(\mathbf{x}_i, \cdot)\}_{i=1}^n$ 中的分量与正交分量。由再生性质，正交分量在所有训练输入上取值为零，去掉它不改变插值条件，却不会增大范数。最小范数函数因而形如 $g = \sum_i a_i K_0(\mathbf{x}_i, \cdot)$ 。插值条件为 $\mathbf{K}_0 \mathbf{a} = \mathbf{r}$ ，故 $\mathbf{a} = \mathbf{K}_0^{-1} \mathbf{r}$ ，且 $\|g\|^2 = \mathbf{a}^\top \mathbf{K}_0 \mathbf{a} = \mathbf{r}^\top \mathbf{K}_0^{-1} \mathbf{r}$ 。对核矩阵作谱分解得到第二个等式。梯度流始终留在上述张成空间中，训练收敛定理又保证插值，因此只能收敛到这个唯一的插值函数。 ■

式 (8.9) 表明，核的谱与标签必须一起分析。同一个小特征值，如果残余标签在它的特征向量上没有分量，就不增加插值范数；若标签在该方向上变化很大，拟合就需要很大的范数。例如

$$\mathbf{K}_0 = \begin{pmatrix} 1 & 1-a \\ 1-a & 1 \end{pmatrix}, \quad 0 < a \leq 1.$$

它的两个特征值为 $2-a$ 和 a 。两个输入的残余标签同为 1 时，插值范数平方为 $2/(2-a)$ ；残余标签分别为 1 和 -1 时，却变为 $2/a$ 。当 a 很小时，

初始梯度认为两个输入非常相似, 要求它们输出相反标签就会显著增加函数复杂度。核矩阵的特征值完全相同, 仅改变标签方向, 得到的泛化上界就可能很不相同。

要把这个函数复杂度转为期望风险, 可以直接使用 Rademacher 复杂度。固定一个与样本无关的核, 并假定 $K_0(\mathbf{x}, \mathbf{x}) \leq \kappa^2$ 。这相当于初始梯度特征的范数不超过 κ 。记 $\mathcal{G}_B = \{g \in \mathcal{H}_{K_0} : \|g\|_{\mathcal{H}_{K_0}} \leq B\}$, 其中 B 在观察样本前确定。

定理 8.9 初始梯度特征的期望风险界 设 $S \sim \mathcal{P}^n$, f_0, K_0 独立于 S , $K_0(\mathbf{x}, \mathbf{x}) \leq \kappa^2$ 。损失 $\ell(u, y) \in [0, 1]$ 关于 u 为 G -Lipschitz。则以概率至少 $1 - \delta$, 对所有 $g \in \mathcal{G}_B$ 同时有

$$R(f_0 + g) \leq \hat{R}_S(f_0 + g) + \frac{2G\kappa B}{\sqrt{n}} + 3\sqrt{\frac{\log(2/\delta)}{2n}}. \quad (8.10)$$

若存在 $g_\star \in \mathcal{G}_B$ 使 $y = f_0(\mathbf{x}) + g_\star(\mathbf{x})$ 几乎处处成立, 且 $\ell(y, y) = 0$, 则在核矩阵几乎必然正定时, 最小范数插值函数 $\hat{g}$ 满足同一上界且经验风险项为零。一个充分样本量条件是

$$n \geq \max \left\{ \frac{16G^2\kappa^2 B^2}{\varepsilon^2}, \frac{18 \log(2/\delta)}{\varepsilon^2} \right\},$$

此时期望风险以概率至少 $1 - \delta$ 不超过 ε 。

证明. 利用再生性质、Cauchy-Schwarz 不等式以及独立随机正负号的交叉项期望为零, 得到

$$\begin{aligned} \hat{\mathcal{R}}_S(\mathcal{G}_B) &= \frac{B}{n} \mathbb{E}_\sigma \left\| \sum_{i=1}^n \sigma_i K_0(\mathbf{x}_i, \cdot) \right\|_{\mathcal{H}_{K_0}} \\ &\leq \frac{B}{n} \sqrt{\sum_{i=1}^n K_0(\mathbf{x}_i, \mathbf{x}_i)} \leq \frac{\kappa B}{\sqrt{n}}. \end{aligned}$$

固定 f_0 产生的偏移与所选函数无关, 故不改变上述复杂度。再由损失的 Lipschitz 收缩性质引入因子 G , 应用有界损失的期望风险界, 即得式 (8.10)。

在可实现条件下, $g_\star$ 本身满足全部插值条件, 故最小范数解满足 $\|\hat{g}\| \leq \|g_\star\| \leq B$, 其经验风险为零。令上界中的两项各不超过 $\varepsilon/2$, 得到样本量条件。 ■

这个结论给出了明确的可学习条件: 真实预测关系能够用初始梯度特征中的小 RKHS 范数函数表示, 核对角有界, 抽样独立同分布, 训练又能到达相应插值解。无限个特征并不妨碍泛化; 控制复杂度的是 κB , 而不是梯度向量有多少个坐标。

核矩阵的谱也提供了可检验的充分条件。在定理的同一个高概率事件上, 只要 $\sum_j (\mathbf{u}_j^\top \mathbf{r})^2 / \lambda_j \leq B^2$, 插值解就属于所控制的函数空间。若这个谱与标签的联合条件本身以概率至少 $1 - \delta_0$ 成立, 结合后的失败概率至多为 $\delta + \delta_0$ 。不能观察样本后任意选 $B = \|\hat{\mathbf{g}}\|$ 而沿用固定 B 的置信度; 事后选择范数尺度需要对一系列事先确定的范数球同时给出保证。

单独要求 $\lambda_{\min}(\mathbf{K}_0) > 0$ 仅保证插值存在。即使粗略使用 $\mathbf{r}^\top \mathbf{K}_0^{-1} \mathbf{r} \leq \|\mathbf{r}\|_2^2 / \lambda_{\min}$, 若 $\|\mathbf{r}\|_2^2$ 随 n 线性增加而最小特征值仅有常数下界, 代入期望风险界也未必得到趋于零的复杂度项。Arora 等对特定过参数化两层网络的分析, 把标签与核谱的联合量用于训练和泛化保证, 并在明确的初始化、宽度和数据条件下得到不显含网络宽度的样本复杂度⁸。

PAC-Bayes 提供另一条严格路径。对有限维初始梯度特征, 固定独立于样本的参数位移先验 $P_0 = \mathcal{N}(0, s^2 \mathbf{I}_p)$, 用 $Q = \mathcal{N}(\hat{\mathbf{v}}, s^2 \mathbf{I}_p)$ 描述训练结果附近的随机参数, 其中 $s > 0$ 事先确定。相对熵为 $\|\hat{\mathbf{v}}\|_2^2 / (2s^2)$ 。定理 8.19 与 Lipschitz 条件给出, 以概率至少 $1 - \delta$, 所有中心 $\hat{\mathbf{v}}$ 同时满足

$$R(\mathbf{g}_{\hat{\mathbf{v}}}) \leq \hat{R}_S(\mathbf{g}_{\hat{\mathbf{v}}}) + 2Gs\kappa + \sqrt{\frac{\|\hat{\mathbf{v}}\|_2^2 / (2s^2) + \log((n+1)/\delta)}{2n}}, \quad (8.11)$$

其中 $\mathbf{g}_{\mathbf{v}} = f_0 + \langle \mathbf{v}, \boldsymbol{\varphi}_0 \rangle$ 。推导中, 投影扰动 $\langle \mathbf{v} - \hat{\mathbf{v}}, \boldsymbol{\varphi}_0(\mathbf{x}) \rangle$ 的绝对值期望不超过 $s\kappa$; 把随机预测的经验风险与期望风险分别转换回中心预测器, 各付出 $Gs\kappa$ 。最小范数参数表示又满足 $\|\hat{\mathbf{v}}\|_2^2 = \|\hat{\mathbf{g}}\|_{\mathcal{H}_{\mathbf{K}_0}}^2$, 所以同一核谱量进入了 PAC-Bayes 复杂度项。

两个界都在评价初始梯度特征中的函数复杂度, 但 PAC-Bayes 还需要权衡扰动损失与相对熵代价, 不能无代价地增大 s 。若插值范数具有统一上界, 可预先令 $s_n = n^{-1/4}$, 使扰动项与相对熵项带来的误差同时趋于零。这个简单构造的速率可以比前面的 Rademacher 界慢, 并不意味着改用 PAC-Bayes 一定得到更紧的保证。上述各向同性高斯构造只在有限维参数空间使用; 无限维 RKHS 中不能直接假定存在协方差为 $s^2 \mathbf{I}$ 的同类高斯概率分布, 可以继续使用前面的 Rademacher 证明。

8.3.4 正则化、稳定性与有限宽度

初始梯度特征不仅能调用核方法的复杂度工具, 也把训练化为前章可处理的凸优化问题。两条路线的对象不同: RKHS 范数控制一类函数, 稳定性控制学习算法更换样本后的输出变化。核在同一次训练中几乎不变, 并不自动意味着两份相邻样本训练出的模型相近。

对线性化模型 $\mathbf{g}_{\mathbf{v}}(\mathbf{x}) = f_0(\mathbf{x}) + \langle \mathbf{v}, \boldsymbol{\varphi}_0(\mathbf{x}) \rangle$ 加入二次正则化, 可以直接使用第 7.4 节的结论。以下固定独立于训练样本的初始化, 并假定 $\|\boldsymbol{\varphi}_0(\mathbf{x})\|_2 \leq \kappa$ 。

⁸ S. Arora, S. S. Du, W. Hu, Z. Li, R. Wang, *Fine-Grained Analysis of Optimization and Generalization for Overparameterized Two-Layer Neural Networks* In Proceedings of the 36th International Conference on Machine Learning, 2019, pp. 322–332

定理 8.10 正则化固定特征模型的稳定性 设损失 $\ell(u, y)$ 关于 u 凸且为 G -Lipschitz。令

$$\hat{\mathbf{v}}_S = \arg \min_{\mathbf{v}} \left\{ \frac{1}{n} \sum_{i=1}^n \ell(\mathbf{g}_{\mathbf{v}}(\mathbf{x}_i), y_i) + \frac{\lambda}{2} \|\mathbf{v}\|_2^2 \right\}, \quad \lambda > 0.$$

若相关期望有限, 则算法的均匀稳定性至多为 $2G^2\kappa^2/(\lambda n)$, 且对任意固定 $\mathbf{v}$,

$$\mathbb{E}_S R(\mathbf{g}_{\hat{\mathbf{v}}_S}) - R(\mathbf{g}_{\mathbf{v}}) \leq \frac{2G^2\kappa^2}{\lambda n} + \frac{\lambda}{2} \|\mathbf{v}\|_2^2.$$

证明. 单个样本损失关于 $\mathbf{v}$ 为 $G\kappa$ -Lipschitz, 经验目标为 λ -强凸。定理 7.42 给出替换一个样本后的参数距离上界 $2G\kappa/(\lambda n)$, 再乘损失的 Lipschitz 常数即得均匀稳定性及期望泛化差上界。正则化最优性还保证

$$\hat{R}_S(\mathbf{g}_{\hat{\mathbf{v}}_S}) \leq \hat{R}_S(\mathbf{g}_{\mathbf{v}}) + \frac{\lambda}{2} \|\mathbf{v}\|_2^2.$$

对样本取期望, 并使用固定 $\mathbf{v}$ 的经验风险期望等于期望风险, 得到结论。■

固定比较半径 $B > 0$, 取 $\lambda = 2G\kappa/(B\sqrt{n})$, 可得

$$\mathbb{E}_S R(\mathbf{g}_{\hat{\mathbf{v}}_S}) - \inf_{\|\mathbf{v}\|_2 \leq B} R(\mathbf{g}_{\mathbf{v}}) \leq \frac{2G\kappa B}{\sqrt{n}}. \quad (8.12)$$

这里的两项分别衡量稳定性代价与正则化造成的比较代价。增大 λ 会改善前者却增大后者; 正则化核学习正是通过这一取舍控制小特征值方向上的放大。该结论针对凸 Lipschitz 损失, 前面的 Rademacher 结论针对有界 Lipschitz 损失, 两者的损失条件与概率要求应分别核对。

有限宽神经网络还需补上近似误差。若实际网络与所分析线性化模型在相关输入上的分数差不超过 τ_n , G -Lipschitz 性使两者期望风险之差至多为 $G\tau_n$ 。只证明训练输入上的核矩阵接近, 不能直接替代对新输入预测误差的控制。因此, 这条路线的完整保证由函数复杂度、经验拟合与固定特征近似三部分组成; 训练显著改变特征时, 就需要进一步分析整个梯度更新过程。

8.4 基于参数梯度更新的可学习性

初始梯度特征理论把训练限制在近似固定的函数空间中。更一般的训练会改变梯度特征本身, 参数化与优化器也会使算法偏向不同的解。此时需要研究从初始化到训练结束的整条更新轨迹, 而不是只计算某个时刻的梯度。

以固定步长的梯度下降为例，迭代关系可以累加为

$$\theta^{(t)} = \theta^{(0)} - \eta \sum_{s=0}^{t-1} \nabla_{\theta} \hat{R}_S(\theta^{(s)}).$$

右侧每个梯度都在前面更新得到的位置计算。即使两个模型在某一时刻具有相同的经验风险，它们的参数化、初始化或此前路径不同，也可能使后续更新走向不同的解。**梯度动力学**（gradient dynamics）研究的正是这些相互依赖的更新怎样塑造最终预测函数。

由初始化、损失、参数化与更新方式共同产生的选解倾向，称为**隐式偏差**（implicit bias，也称隐式偏置）。这里的“偏差”指算法选择哪些解，与期望风险分解中的近似误差不同。它也不等于某一步更新：平方损失可能使线性模型趋向最小欧氏范数插值解，逻辑损失可能使分类方向趋向最大间隔解，矩阵分解参数化则可能改变奇异值的增长速度。

这些几何性质还要与泛化理论连接。一条路径先说明参数更新选择什么解，再证明所选结构怎样控制期望风险，这构成“隐式偏差—复杂度或风险分析”路线。另一条路径直接研究训练输出对样本替换是否稳定，由此控制泛化差。

8.4.1 参数更新、隐式偏差与泛化路径

参数更新影响泛化，不是因为“使用了梯度下降”本身就能保证新样本上的表现，而是因为初始化、损失、参数化和优化器共同决定了算法最终偏向哪一类解。以下三条路线分别研究不同场景中的这种隐式偏差：线性平方损失选择有限的最小范数插值解，线性可分数据上的逻辑损失选择发散参数的最大间隔方向，矩阵分解参数化则改变端到端矩阵的谱演化。三者不是连续步骤，也不会共同通向核范数；它们都从参数更新出发，但需要各自的统计条件和泛化工具。

这三条路线共享式(8.2)中的风险分解。参数更新可以通过两种方式控制其中的期望泛化差：一是证明它选择了具有可控范数、间隔或谱结构的解，再调用相应风险界；二是直接证明映射 $S \mapsto A(S)$ 具有算法稳定性。若算法还含有内部随机性，相应期望也要对该随机性计算。下面三节展开第一种方式，最后一节讨论第二种。

8.4.2 最小范数与线性回归泛化

只有一条观测 $\mathbf{x} = (1, 1)^T, y = 1$ 时，线性预测的插值条件是 $w_1 + w_2 = 1$ 。参数 $(1, 0)^T$ 、 $(0, 1)^T$ 和 $(1/2, 1/2)^T$ 都满足它，却对新输入 $(1, 0)^T$ 分别预测 1、0 和 1/2。从零初始化出发，平方损失的两个梯度分量始终相同，所以梯度下降保持 $w_1 = w_2$ ，最终只能选择 $(1/2, 1/2)^T$ 。这个解的欧氏范数最

小，因为其他解 $(1/2 + a, 1/2 - a)^\top$ 的范数平方为 $1/2 + 2a^2$ 。

图 8.6 把插值条件画成参数平面上的一条直线。从零初始化的更新始终沿 $w_1 = w_2$ 前进，落到直线上距离原点最近的点；同一直线上的其他参数虽然也能拟合训练观测，对新输入的预测却不同。




图 8.6 一个训练观测对应多个插值参数。直线上的 A、B、C 都使输入 $(1, 1)^\top$ 的预测为 1，右侧列出它们对同一新输入 $\mathbf{x}_{\text{new}} = (1, 0)^\top$ 的预测。对半平方损失从零初始化，图中以步长 $1/4$ 画出前三次更新，轨迹趋向 B；细弧表示经过 B 的欧氏范数等值线，说明 B 是插值直线上距离原点最近的点。这个教学例子解释选解规则，不给出新输入的真实标签或泛化保证。

定理 8.11 梯度下降的最小范数选择 设 $\mathbf{X} \in \mathbb{R}^{n \times d}$ 满行秩， $d > n$ 。

对 $\hat{R}_S(\mathbf{w}) = \|\mathbf{X}\mathbf{w} - \mathbf{y}\|_2^2 / (2n)$ ，梯度下降从 $\mathbf{w}^{(0)} = \mathbf{0}$ 出发，使用步长 $0 < \eta < 2n / \|\mathbf{X}\|_2^2$ ，则

$$\mathbf{w}^{(t)} \longrightarrow \hat{\mathbf{w}} = \mathbf{X}^\top (\mathbf{X}\mathbf{X}^\top)^{-1} \mathbf{y} = \arg \min_{\mathbf{X}\mathbf{w}=\mathbf{y}} \|\mathbf{w}\|_2. \quad (8.13)$$

证明. 每次更新的增量为 $-\eta \mathbf{X}^\top (\mathbf{X}\mathbf{w}^{(t)} - \mathbf{y}) / n$ ，故所有迭代都在 $\text{range}(\mathbf{X}^\top)$ 内。残差满足

$$\mathbf{e}^{(t+1)} = \left(\mathbf{I} - \frac{\eta}{n} \mathbf{X}\mathbf{X}^\top \right) \mathbf{e}^{(t)}.$$

满行秩使 $\mathbf{X}\mathbf{X}^\top$ 正定；步长条件使括号内全部特征值的绝对值小于 1，所以残差趋于零。在上述行空间内，插值解唯一，正是式 (8.13) 中的 $\hat{\mathbf{w}}$ 。任意其他插值解均可写成

$$\mathbf{w} = \hat{\mathbf{w}} + \mathbf{v}, \quad \mathbf{v} \in \text{null}(\mathbf{X}). \quad (8.14)$$

行空间与零空间正交，故 $\|\mathbf{w}\|_2^2 = \|\hat{\mathbf{w}}\|_2^2 + \|\mathbf{v}\|_2^2$ 。这证明了最小范数性质。■

零初始化是结论的一部分。若初始参数已经含有零空间分量，梯度更新

不会消除它，最终结果也就未必是最小范数解。对深层网络改变参数化，等价函数对应的参数范数也可能不同，因此不能把线性模型的选择规则直接移用于所有网络。

最小范数选择解释了梯度下降最终输出什么，还没有回答这个输出在新输入上是否准确。要继续分析，必须把选出的参数代回期望风险。线性回归允许把这一步完整写出，也能显示为什么隐式偏差没有一个脱离数据分布的统一样本量公式。

设真实标签满足 $y = \mathbf{x}^\top \mathbf{w}_\star + \xi$ ，噪声均值为零、方差为 σ^2 ，并与输入独立。令 $\Sigma = \mathbb{E}[\mathbf{x}\mathbf{x}^\top]$ 。以下使用完整平方损失 $(\mathbf{x}^\top \mathbf{w} - y)^2$ 定义期望风险；它与前面优化目标中的半平方损失只相差常数，不改变梯度下降的最小范数极限。由于新观测的噪声与输入独立，展开平方可得

$$R(\mathbf{w}) - R(\mathbf{w}_\star) = \|\mathbf{w} - \mathbf{w}_\star\|_\Sigma^2, \quad \|\mathbf{v}\|_\Sigma^2 = \mathbf{v}^\top \Sigma \mathbf{v}.$$

参数误差对预测的影响取决于输入在哪些方向上变化，不能只看欧氏距离。

定理 8.12 基于最小范数的回归期望风险 在上述线性回归模型中，固定满行秩设计矩阵 $\mathbf{X} \in \mathbb{R}^{n \times d}$ ， $n < d$ ，训练标签为 $\mathbf{y} = \mathbf{X}\mathbf{w}_\star + \xi$ ，其中 $\mathbb{E}[\xi | \mathbf{X}] = 0$ 、 $\mathbb{E}[\xi\xi^\top | \mathbf{X}] = \sigma^2 \mathbf{I}$ 。令 $\hat{\mathbf{w}} = \mathbf{X}^\top(\mathbf{X}\mathbf{X}^\top)^{-1}\mathbf{y}$ ， $\mathbf{P}_X = \mathbf{X}^\top(\mathbf{X}\mathbf{X}^\top)^{-1}\mathbf{X}$ 。则

$$\begin{aligned} \mathbb{E}_{\xi|\mathbf{X}}[R(\hat{\mathbf{w}}) - R(\mathbf{w}_\star)] \\ = \|(I - \mathbf{P}_X)\mathbf{w}_\star\|_\Sigma^2 + \sigma^2 \text{tr}[\Sigma \mathbf{X}^\top(\mathbf{X}\mathbf{X}^\top)^{-2}\mathbf{X}]. \end{aligned} \quad (8.15)$$

证明. 把训练标签代入最小范数解，有

$$\hat{\mathbf{w}} - \mathbf{w}_\star = -(I - \mathbf{P}_X)\mathbf{w}_\star + \mathbf{X}^\top(\mathbf{X}\mathbf{X}^\top)^{-1}\xi.$$

在 Σ 半范数下展开平方。条件噪声均值为零，使交叉项的期望为零；利用 $\mathbb{E}[\xi\xi^\top | \mathbf{X}] = \sigma^2 \mathbf{I}$ 计算最后一项，就得到迹表达式。 ■

若设计矩阵本身也由输入分布随机抽取，且式 (8.15) 右侧可积，再对 $\mathbf{X}$ 取期望即可得到完整训练样本随机性下的超额期望风险。第一项来自样本没有确定的目标方向：梯度下降从零出发，不会补出 $\mathbf{X}$ 零空间中的目标分量。第二项来自对训练噪声的拟合，其中的矩阵逆可能放大某些方向上的噪声。因此，“算法偏向最小范数”不能单独排除这两类预测误差。如果把零一损失下的期望风险范数界直接套在这个平方损失问题上，也无法代替当前的分布分析。

数据各方向的重要程度会影响这两项误差。Bartlett 等关于良性过拟合

的研究说明,在特定协方差谱条件下,最小范数插值可以在拟合噪声的同时保持较低的超额期望风险⁹。隐式偏差对样本量的指导因此必须包括“算法选择什么解”以及“数据如何评价这个解”两部分;它不是另一个只需代入参数总数的容量公式。

无噪声、各方向同等重要的情形提供了一个可以算出样本量的例子。若 $\mathbf{x}_i \sim \mathcal{N}(0, \mathbf{I}_d)$ 且 $\sigma = 0$, 则 $\Sigma = \mathbf{I}_d$ 。随机样本张成的 n 维子空间没有优先方向,因而 $\mathbb{E}\mathbf{P}_X = (n/d)\mathbf{I}_d$: 旋转对称性使期望投影矩阵为单位矩阵的倍数,而 $\text{tr}(\mathbf{P}_X) = n$ 确定了这个倍数。于是

$$\mathbb{E}_S[R(\hat{\mathbf{w}}) - R(\mathbf{w}_\star)] = \left(1 - \frac{n}{d}\right) \|\mathbf{w}_\star\|_2^2, \quad n < d. \quad (8.16)$$

当 $\|\mathbf{w}_\star\|_2 = 1$ 、 $d = 100$ 、 $n = 10$ 时,经验平方风险为零,但平均超额期望风险仍为 0.9。在这个特定模型中,要使它不超过 $\varepsilon < 1$, 需要 $n \geq d(1 - \varepsilon)$ 。这里是由精确表达式得到的条件,说明最小范数偏好本身不会自动消除对维度的依赖。

8.4.3 最大间隔与线性分类泛化

平方损失在达到插值后可以取得有限的参数极限,分类中的逻辑损失则会产生另一种行为。对线性可分数据,沿正确分类的方向不断放大参数,就能继续降低 $\log(1 + e^{-y\mathbf{w}^\top \mathbf{x}})$ 。因此,经验风险的下确界虽为零,却未必存在达到它的有限参数;需要研究归一化方向,而不是等待参数本身收敛。

令标签为 $y_i \in \{-1, 1\}$, 线性可分指存在 $\mathbf{w}$ 使全部 $y_i \mathbf{w}^\top \mathbf{x}_i > 0$ 。方向 $\mathbf{u}$ 满足 $\|\mathbf{u}\|_2 = 1$ 时,其最小经验间隔是 $\min_i y_i \mathbf{u}^\top \mathbf{x}_i$ 。固定所有样本的未归一化间隔至少为 1,再最小化参数范数,便等价于最大化这个方向间隔。这就是硬间隔支持向量机的几何目标。

定理 8.13 逻辑回归梯度下降的最大间隔方向 设有限样本线性可分, $\mathbf{X}$ 以 $\mathbf{x}_i^\top$ 为第 i 行。对

$$\hat{R}_S(\mathbf{w}) = \frac{1}{n} \sum_{i=1}^n \log(1 + e^{-y_i \mathbf{w}^\top \mathbf{x}_i})$$

从任意有限初始化作梯度下降,取 $0 < \eta < n/\|\mathbf{X}\|_2^2$ 。则 $\|\mathbf{w}^{(t)}\|_2 \rightarrow \infty$, 且

$$\frac{\mathbf{w}^{(t)}}{\|\mathbf{w}^{(t)}\|_2} \rightarrow \frac{\hat{\mathbf{w}}_{\text{svm}}}{\|\hat{\mathbf{w}}_{\text{svm}}\|_2},$$

其中

$$\hat{\mathbf{w}}_{\text{svm}} = \arg \min_{\mathbf{w}} \frac{1}{2} \|\mathbf{w}\|_2^2 \quad \text{满足} \quad y_i \mathbf{w}^\top \mathbf{x}_i \geq 1 \quad (1 \leq i \leq n).$$

⁹ P. L. Bartlett, P. M. Long, G. Lugosi, A. Tsigler, *Benign Overfitting in Linear Regression* In Proceedings of the National Academy of Sciences, 2020, vol. 117, no. 48, pp. 30063–30070

证明（使用外部渐近结果）。采用 Soudry 等对可分逻辑回归证明的渐近展开，在上述保守步长条件下， $\mathbf{w}^{(t)} = \hat{\mathbf{w}}_{\text{svm}} \log t + \boldsymbol{\rho}^{(t)}$ ，其中 $\|\boldsymbol{\rho}^{(t)}\|_2 = O(\log \log t)^{10}$ 。由于 $\log \log t / \log t \rightarrow 0$ ，除以 $\log t$ 后取极限得到 $\hat{\mathbf{w}}_{\text{svm}}$ 。该向量非零，故参数范数发散，并且归一化方向收敛到所述方向。这里的渐近展开是所引用的外部结果，本段只证明由该展开到方向收敛的推论。■

梯度公式能够解释最大间隔为何出现：

$$-\nabla \hat{R}_S(\mathbf{w}) = \frac{1}{n} \sum_{i=1}^n \frac{y_i \mathbf{x}_i}{1 + e^{y_i \mathbf{w}^\top \mathbf{x}_i}}.$$

已经具有较大间隔的样本获得很小的更新权重，接近分类边界的样本则持续影响更新。因而，即使分类经验风险已经为零，逻辑经验风险的优化仍会改变分类方向。这一解释展示了动力学的作用，但不能代替证明方向极限存在的渐近分析。

最大间隔方向可以通过前面的复杂度理论转为期望风险保证。

定理 8.14 基于最大间隔的分类期望风险 设 $S \sim \mathcal{P}^n$ 独立同分布，且 $\|\mathbf{x}\|_2 \leq r$ 几乎处处成立。事先固定 $\gamma > 0$ 和 $\delta \in (0, 1)$ 。则以概率至少 $1 - \delta$ ，所有满足 $\|\mathbf{u}\|_2 = 1$ 的方向同时满足

$$\begin{aligned} R^{01}(\text{sign}(\langle \mathbf{u}, \cdot \rangle)) &\leq \frac{1}{n} \sum_{i=1}^n \mathbf{1}\{y_i \mathbf{u}^\top \mathbf{x}_i \leq \gamma\} \\ &\quad + \frac{2r}{\gamma\sqrt{n}} + 3\sqrt{\frac{\log(2/\delta)}{2n}}. \end{aligned} \quad (8.17)$$

证明. 单位范数线性函数类的经验 Rademacher 复杂度至多为 $r/\sqrt{n}$ 。取在负间隔处为 1、从 0 到 γ 线性下降、在不小于 γ 处为 0 的间隔损失。它以 $1/\gamma$ 为 Lipschitz 常数，上界控制零一损失，而它在训练样本上的取值又不超过 $\mathbf{1}\{y_i \mathbf{u}^\top \mathbf{x}_i \leq \gamma\}$ 。对该损失应用 Rademacher 复杂度的 Lipschitz 收缩和统一期望风险界，即得结论。■

若最大经验方向间隔大于这个预先确定的 γ ，定理 8.13 保证充分训练后式 (8.17) 第一项为零。此时使期望分类错误率不超过 ε 的充分样本量具有 $O((r^2/\gamma^2 + \log(1/\delta))/\varepsilon^2)$ 的量级。

这里依赖的是归一化间隔，并非参数范数本身变小。参数整体放大会同时放大原始间隔和范数，不能改善二者之比；梯度动力学改变方向才可能改善该比值。训练样本可分也不意味着间隔具有与样本量无关的正下界；若只是借助高维特征记住噪声，所得间隔可能很小，上界仍可能无效。存在标签噪声、改变优化器或使用深层参数化时，必须重新核对选解结论。

¹⁰ D. Soudry, E. Hoffer, M. S. Nacson, S. Gunasekar, N. Srebro, *The Implicit Bias of Gradient Descent on Separable Data* In Journal of Machine Learning Research, 2018, vol. 19, no. 70, pp. 1–57

8.4.4 谱偏好与矩阵预测的泛化

深层线性网络没有非线性激活，但仍具有非线性的参数优化过程。若 $\mathbf{W} = \mathbf{W}_L \cdots \mathbf{W}_1$ ，网络输出为 $\mathbf{W}\mathbf{x}$ ；不同层数可以表示同一个端到端线性映射，却可能经梯度训练得到不同的映射。原因是对各因子求导后，其他层的矩阵会进入更新公式。

为清楚展示这种作用，先令 $\mathbf{W} = \mathbf{U}\mathbf{V}^\top$ ，经验目标写为 $\mathcal{L}(\mathbf{W})$ ，并记 $\mathbf{G} = \nabla_{\mathbf{W}}\mathcal{L}$ 。梯度流满足

$$\dot{\mathbf{U}} = -\mathbf{G}\mathbf{V}, \quad \dot{\mathbf{V}} = -\mathbf{G}^\top\mathbf{U}.$$

对乘积求导可得

$$\dot{\mathbf{W}} = -\mathbf{G}\mathbf{V}\mathbf{V}^\top - \mathbf{U}\mathbf{U}^\top\mathbf{G}. \quad (8.18)$$

直接优化 $\mathbf{W}$ 时，梯度流只有 $-\mathbf{G}$ ；分解参数化则在梯度两侧乘上随训练变化的矩阵，使不同方向具有不同的有效更新速度。这种变化可以在完整轨迹中累积，即使目标函数没有显式范数惩罚也会发生。

矩阵的奇异值衡量它在不同输入输出方向上的作用强度。只有少量非零奇异值时，矩阵为低秩；只有少量显著奇异值时，可以用低秩矩阵近似它。对多输出线性预测或矩阵观测问题，这意味着多个预测方向共享较少的线性结构。标量输出线性模型的端到端矩阵本来就只有一行，不能用同一种低秩解释来描述它的全部泛化行为。

对深层乘积，可以在平衡初始化下精确写出奇异值动力学。这里的平衡指相邻层满足 $\mathbf{W}_{j+1}^\top\mathbf{W}_{j+1} = \mathbf{W}_j\mathbf{W}_j^\top$ ，即相邻因子的内积结构相配。这个条件为以下推导提供了可处理的几何结构，不能在任意初始化上省略。

定理 8.15 平衡深层线性网络的梯度流 设各层为方阵， $\mathcal{L}$ 可微，因子按 $\mathcal{L}(\mathbf{W}_L \cdots \mathbf{W}_1)$ 的梯度流演化，并在初始化满足上述平衡条件。记 $\mathbf{W} = \mathbf{W}_L \cdots \mathbf{W}_1$ 、 $\mathbf{G} = \nabla\mathcal{L}(\mathbf{W})$ 。在解存在且各层满秩的时间区间内，平衡关系保持，且

$$\dot{\mathbf{W}} = -\sum_{j=1}^L (\mathbf{W}\mathbf{W}^\top)^{(L-j)/L} \mathbf{G} (\mathbf{W}^\top\mathbf{W})^{(j-1)/L}. \quad (8.19)$$

在某个正奇异值 σ_k 为单重且可微的时刻，若其左右奇异向量为 $\mathbf{u}_k, \mathbf{v}_k$ ，则

$$\dot{\sigma}_k = -L\sigma_k^{2-2/L} \mathbf{u}_k^\top \mathbf{G} \mathbf{v}_k. \quad (8.20)$$

证明. 写 $\mathbf{A}_j = \mathbf{W}_L \cdots \mathbf{W}_{j+1}$ 、 $\mathbf{B}_j = \mathbf{W}_{j-1} \cdots \mathbf{W}_1$ ，空乘积取单位矩阵。链式

法则给出 $\dot{\mathbf{W}}_j = -\mathbf{A}_j^\top \mathbf{G} \mathbf{B}_j^\top$, 故

$$\dot{\mathbf{W}} = -\sum_j \mathbf{A}_j \mathbf{A}_j^\top \mathbf{G} \mathbf{B}_j^\top \mathbf{B}_j.$$

将同一导数代入相邻层的 Gram 矩阵, 可核对 $\frac{d}{dt}(\mathbf{W}_{j+1}^\top \mathbf{W}_{j+1} - \mathbf{W}_j \mathbf{W}_j^\top) = 0$ 。平衡关系因而始终成立, 并允许将各层写为相互匹配的奇异值分解 $\mathbf{W}_j = \mathbf{U}_j \mathbf{D} \mathbf{U}_{j-1}^\top$ 。于是 $\mathbf{W} = \mathbf{U}_L \mathbf{D}^L \mathbf{U}_0^\top$, 而 $\mathbf{A}_j \mathbf{A}_j^\top = (\mathbf{W} \mathbf{W}^\top)^{(L-j)/L}$ 、 $\mathbf{B}_j^\top \mathbf{B}_j = (\mathbf{W}^\top \mathbf{W})^{(j-1)/L}$ 。代回乘积导数得到第一式。再用单重奇异值的微分关系 $\dot{\sigma}_k = \mathbf{u}_k^\top \dot{\mathbf{W}} \mathbf{v}_k$, 每个求和项均贡献 $-\sigma_k^{2-2/L} \mathbf{u}_k^\top \mathbf{G} \mathbf{v}_k$, 得到第二式。 ■

式 (8.20) 显示, 在其余梯度投影相当时, 小奇异值方向的更新被更强地抑制, 大奇异值方向则变化较快。它解释了某些训练过程中少数方向先成长的现象。梯度投影的符号和大小也会变化, 所以该式本身不保证任意数据上最终都取得最低秩解。Arora 等从深层矩阵分解的动力学研究了这类谱偏好; 实际离散训练还需要控制步长与平衡近似¹¹。

低秩与小核范数有关, 但并不相同。**核范数** (nuclear norm) 是矩阵全部奇异值之和, 记作 $\|\mathbf{W}\|_*$; 此处的“核”与 NTK 的核函数无关。若秩不超过 q 且 $\|\mathbf{W}\|_F \leq F$, Cauchy-Schwarz 不等式给出 $\|\mathbf{W}\|_* \leq \sqrt{q}F$ 。降低秩只有在矩阵尺度同时受控时, 才能据此减小核范数。

因子参数的大小与核范数之间存在一个精确的静态关系。

引理 8.16 二层分解的范数关系 对任意矩阵 $\mathbf{W}$, 若分解的中间维数不小于 $\text{rank}(\mathbf{W})$, 则

$$\|\mathbf{W}\|_* = \min_{\mathbf{U}\mathbf{V}^\top = \mathbf{W}} \frac{1}{2}(\|\mathbf{U}\|_F^2 + \|\mathbf{V}\|_F^2).$$

证明. 核范数与谱范数的对偶关系以及 Cauchy-Schwarz 不等式给出 $\|\mathbf{U}\mathbf{V}^\top\|_* \leq \|\mathbf{U}\|_F \|\mathbf{V}\|_F$, 再用 $ab \leq (a^2 + b^2)/2$ 得到下界。若 $\mathbf{W} = \mathbf{P}\mathbf{\Sigma}\mathbf{Q}^\top$ 是紧奇异值分解, 取 $\mathbf{U} = \mathbf{P}\mathbf{\Sigma}^{1/2}$ 、 $\mathbf{V} = \mathbf{Q}\mathbf{\Sigma}^{1/2}$, 两因子的范数平方都等于 $\text{tr } \mathbf{\Sigma}$, 从而达到等号。 ■

这个引理说明, 显式最小化二层因子的平方范数之和, 可以转化为端到端矩阵的核范数最小化。它没有证明只优化经验损失的梯度流也会最小化这个量。Gunasekar 等的相关结论需要观测矩阵两两可交换 (交换乘法顺序不改变乘积)、趋于零的初始化及插值极限存在等条件¹²。这些条件不能从链式法则本身推出。

更一般地, 动力学偏好未必能用某个范数最小化完整表达。Razin 与 Cohen 构造了矩阵分解问题, 平方损失下的经验风险趋于零时, 所有矩阵范数都可发散¹³。因而, 低秩趋势、核范数控制和显式范数正则化应分别

¹¹ S. Arora, N. Cohen, W. Hu, Y. Luo, *Implicit Regularization in Deep Matrix Factorization* In *Advances in Neural Information Processing Systems*, 2019

¹² S. Gunasekar, B. E. Woodworth, S. Bhojanapalli, B. Neyshabur, N. Srebro, *Implicit Regularization in Matrix Factorization* In *Advances in Neural Information Processing Systems*, 2017

¹³ N. Razin, N. Cohen, *Implicit Regularization in Deep Learning May Not Be Explainable by Norms* In *Advances in Neural Information Processing Systems*, 2020

证明；把深层梯度更新一概等同于隐式核范数惩罚，会遗漏这些情形。

一旦确实能够证明训练输出具有较小核范数，就可以接上期望风险分析。考虑以矩阵 $\mathbf{A}$ 为输入、以 $h_{\mathbf{W}}(\mathbf{A}) = \langle \mathbf{W}, \mathbf{A} \rangle_F$ 为预测的学习问题，其中内积为对应元素乘积之和。这包括矩阵观测问题： $\mathbf{A}$ 可以指定需要预测的一个矩阵元素，也可以描述对多个元素的线性观测。

核范数约束能够控制矩阵预测的幅度。把 $\mathbf{W}$ 分解为奇异值与秩一方向之和，每个单位方向上的 $|\mathbf{u}^\top \mathbf{A} \mathbf{v}|$ 都不超过 $\|\mathbf{A}\|_2$ ，所以

$$|\langle \mathbf{W}, \mathbf{A} \rangle_F| \leq \|\mathbf{W}\|_* \|\mathbf{A}\|_2.$$

若把全部核范数分配给 $\mathbf{A}$ 最大奇异值对应的方向，还能达到等号。这就是下面证明使用的核范数与谱范数对偶关系：一项限制模型的总奇异值大小，另一项衡量输入在最强方向上的作用。

定理 8.17 基于谱结构的矩阵预测期望风险 设样本独立同分布， $\|\mathbf{A}\|_F \leq r$ ，损失取值于 $[0, 1]$ 且关于预测值为 G -Lipschitz。固定 $B > 0$ ，以概率至少 $1 - \delta$ ，所有 $\|\mathbf{W}\|_* \leq B$ 同时满足

$$R(h_{\mathbf{W}}) \leq \hat{R}_S(h_{\mathbf{W}}) + \frac{2GBr}{\sqrt{n}} + 3\sqrt{\frac{\log(2/\delta)}{2n}}.$$

特别地，若对某个矩阵分解训练算法另行证明其输出 $\mathbf{W}_S$ 满足 $\|\mathbf{W}_S\|_* \leq B$ ，则 $\mathbf{W}_S$ 服从同一个期望风险界。若进一步规定 $\text{rank}(\mathbf{W}) \leq q$ 且 $\|\mathbf{W}\|_F \leq F$ ，可将复杂度项中的 B 取为 $\sqrt{q}F$ 。

证明. 由核范数与谱范数的对偶关系，预测函数空间的经验 Rademacher 复杂度为

$$\frac{B}{n} \mathbb{E}_\sigma \left\| \sum_{i=1}^n \sigma_i \mathbf{A}_i \right\|_2 \leq \frac{B}{n} \sqrt{\sum_{i=1}^n \|\mathbf{A}_i\|_F^2} \leq \frac{Br}{\sqrt{n}}.$$

其中先用谱范数不超过 Frobenius 范数，再利用随机正负号使平方展开的交叉项期望为零。对损失应用 Lipschitz 收缩与经验 Rademacher 期望风险界，即得结论。低秩情形由 $\|\mathbf{W}\|_* \leq \sqrt{q}\|\mathbf{W}\|_F$ 得到。 ■

若训练输出满足所分析的核范数约束，使期望风险与经验风险之间的附加项不超过 ε ，充分样本量具有 $O((G^2 B^2 r^2 + \log(1/\delta))/\varepsilon^2)$ 的量级。秩为 q 且尺度受控时，相应项为 $G^2 q F^2 r^2$ 。这给出了低秩结构可能改善泛化的具体入口，但 F 、 r 自身也可能随矩阵大小增加，不能把公式读成无条件摆脱维度。

该界评价观测分布上的预测误差；若希望恢复整个未知矩阵，还需要观测覆盖、噪声和目标结构等条件。完整论证因此是：梯度动力学在规定初

始化与数据条件下选出某类矩阵，再证明其核范数或其他复杂度受控，最后用学习理论给出期望风险。链式法则解释更新的几何结构，不能独自完成可学习性的全部证明。

8.4.5 参数更新的稳定性与泛化

偏好最小范数解，并不自动意味着算法对样本稳定。固定设计矩阵 $\mathbf{X}$ ，只改变标签 $\mathbf{y}$ 为 $\mathbf{y} + \Delta\mathbf{y}$ 时，最小范数解的变化满足

$$\Delta\hat{\mathbf{w}} = \mathbf{X}^\top(\mathbf{X}\mathbf{X}^\top)^{-1}\Delta\mathbf{y}, \quad \|\Delta\hat{\mathbf{w}}\|_2 \leq \frac{\|\Delta\mathbf{y}\|_2}{\sigma_{\min}(\mathbf{X})}.$$

这里 $\sigma_{\min}(\mathbf{X})$ 是最小非零奇异值；上界来自奇异值分解。如果它很小，少量标签变化仍可能显著改变参数。一般的样本替换还会改变 $\mathbf{X}$ ，需要更多控制，所以上式只是识别敏感方向的一个简单例子。

第 7.3 节给出的参数稳定性途径，在这种场景下要求进一步证明参数变化足够小，再用损失的 Lipschitz 性质转换为期望泛化差。反过来，逻辑回归的参数范数持续增大时，分类方向仍可能逐渐稳定，说明原始参数距离也未必是最合适的度量。可以转向预测函数或损失的稳定性。

如果已经证明训练算法具有平均参数稳定性 $\bar{\alpha}_n$ ，损失关于参数为 L_θ -Lipschitz，且经验优化误差不超过 ρ_n ，前章定理 7.27 便给出

$$\mathbb{E}_S R(A(S)) - \inf_{h \in \mathcal{H}} R(h) \leq L_\theta \bar{\alpha}_n + \rho_n.$$

在深层网络中，还可以使用定理 8.5，把参数变化按层传递到损失。隐式偏差的作用在于帮助确定和分析这条选解映射 $S \mapsto A(S)$ ，稳定性定理负责将映射对样本的敏感程度转成期望风险保证。这里需要的是前章定义中相应的平均参数稳定性，不能用单次训练中相邻迭代的距离代替。

这也说明了训练上的取舍。改变初始化、优化器或参数化，可能改变所偏好的范数或间隔，从而改变泛化；但必须检验经验风险、所选解的预测性质及样本敏感性。在可分逻辑回归中，继续训练可能增大归一化间隔，同时使原始参数范数发散，所以只监测参数范数变小并不是普遍适用的训练准则。

对于矩阵分解，不同因子组合可以表示同一个端到端矩阵。因此，因子参数的变化与预测函数的变化也应分开；若只关心预测，可以直接分析端到端矩阵或损失对样本替换的敏感程度。

梯度动力学回答算法偏向哪一种解，稳定性回答这种选解对样本变化有多敏感。二者可以共同解释泛化，但任何一项都不能省去数据条件和期望风险分析。在双重下降的过参数化区域，最小范数选择是否带来低期望风险，同样取决于数据的谱结构、噪声及目标函数，而不只是参数数量超

过样本数量。

8.5 基于参数分布的可学习性

8.5.1 参数分布的两种语义

上一节把训练结果写成一个参数点，研究更新规则怎样选择这个点。对于宽网络，逐个追踪大量神经元既难以揭示整体特征变化，也未必适合描述训练结果附近的一组相似预测器。参数分布提供了另一种分析语言，但“分布”在这里有两种不同语义。

一种分布以单个神经元为基本单位。把同一网络中的神经元参数汇总为经验分布 ρ ，再对神经元输出积分，得到一个确定性预测器 f_ρ ；平均场理论研究训练怎样推动 ρ 演化。另一种分布以完整网络为基本单位。PAC-Bayes 中的后验 Q 在完整参数向量之间随机取值，从 Q 抽取一次才得到一个预测器。前者把分布作为网络的表示，后者把分布作为学习算法的随机输出，二者不能仅因都定义在参数空间上就视为同一个对象。

当分析相邻训练集产生的同类分布时，可以使用一阶 Wasserstein 距离。对同一度量空间上的概率分布 μ, ν ，定义

$$W_1(\mu, \nu) = \inf_{\pi \in \Pi(\mu, \nu)} \mathbb{E}_{(\mathbf{u}, \mathbf{v}) \sim \pi} \|\mathbf{u} - \mathbf{v}\|_2,$$

其中 $\Pi(\mu, \nu)$ 是所有边缘分布分别为 μ, ν 的联合分布。这个距离寻找两组参数之间平均代价最小的配对。不过， $W_1(\rho_S, \rho_{S'})$ 比较的是神经元群体， $W_1(Q_S, Q_{S'})$ 比较的是完整网络随机输出；记号相同不表示两者位于同一个空间。

两种分布也对应不同的泛化论证。平均场分析必须进一步说明神经元分布的变化怎样控制预测函数，并结合复杂度或样本稳定性得到泛化结论；PAC-Bayes 则比较完整网络后验与样本独立先验，用相对熵控制随机预测器的经验风险与期望风险之差。本节先分别建立这两条路线，再说明其中出现的 Wasserstein 距离、相对熵和互信息各自在比较什么。

8.5.2 神经元分布与平均场泛化

如果大量神经元在训练中持续改变各自的特征，逐个追踪参数既复杂，也不容易观察整体规律。平均场方法记录不同神经元参数在参数空间中的分布，再研究这一分布怎样随训练变化。

考虑具有 m 个隐藏单元的两层网络，并采用 $1/m$ 的输出缩放：

$$f_m(\mathbf{x}) = \frac{1}{m} \sum_{j=1}^m a_j \phi(\mathbf{w}_j^\top \mathbf{x}).$$

把每个神经元的参数对 $(a_j, \mathbf{w}_j)$ 看作参数空间中的一个点，赋予它质量 $1/m$ ，得到经验分布 $\rho_m = m^{-1} \sum_{j=1}^m \delta_{(a_j, \mathbf{w}_j)}$ 。这里 $\delta_{(a, \mathbf{w})}$ 是集中在一个参数点上的概率分布。于是网络可写成

$$f_{\rho_m}(\mathbf{x}) = \int a \phi(\mathbf{w}^\top \mathbf{x}) d\rho_m(a, \mathbf{w}). \quad (8.21)$$

例如，一半神经元使用参数 $(a_1, \mathbf{w}_1)$ 、另一半使用 $(a_2, \mathbf{w}_2)$ 时，输出就是两种神经元输出的平均；在同样比例下复制神经元，并不改变这个积分。

平均场理论 (mean-field theory) 研究适当缩放下，有限神经元分布 ρ_m 接近连续分布 ρ 时的学习与训练动力学。Mei 等给出了两层网络的相关极限分析及有限宽度近似结果¹⁴。与固定核近似不同， ρ 的质量可以在训练中移动，因而 $\mathbf{w}$ 所表示的特征也可以改变。这为分析特征学习提供了途径。两种理论对应不同的缩放和训练状态，并不是“宽网络一定服从 NTK、窄网络才发生特征学习”。

分布表示还揭示了一种有用结构： f_ρ 对 ρ 线性，所以当损失关于预测值凸时，期望风险作为分布 ρ 的函数也具有凸性。不过，有限网络通过移动有限个神经元位置来优化，仍可能面对非凸参数化。分布层面的凸性并不能直接证明普通梯度下降达到全局最优，更不能单独证明泛化。

要从神经元分布的训练动力学得到泛化结论，还需分析训练数据变化后 ρ 怎样变化。若单元输出 $\psi_\theta(\mathbf{x})$ 关于神经元参数 θ 一致为 L_ψ -Lipschitz，损失关于网络输出为 G -Lipschitz，且替换一条样本所得的神经元分布满足 $W_1(\rho_S, \rho_{S'}) \leq a_n$ ，则

$$|\mathbb{E}_S[R(f_{\rho_S}) - \hat{R}_S(f_{\rho_S})]| \leq GL_\psi a_n.$$

这是因为，对神经元参数的任意配对 $\pi \in \Pi(\rho_S, \rho_{S'})$ 都有

$$|f_{\rho_S}(\mathbf{x}) - f_{\rho_{S'}}(\mathbf{x})| \leq L_\psi \mathbb{E}_\pi \|\theta - \theta'\|_2.$$

对 π 取下确界，再用损失的 Lipschitz 性质和第 7.3 节的替换样本恒等式，即得上述期望泛化差。单元输出的 Lipschitz 条件通常还要求输入与神经元参数受到适当约束。

这个结论给出了平均场与泛化之间缺少的第一步：平均场极限描述神经元分布怎样演化，样本稳定性则说明这种演化是否会因一条训练样本的变化而显著改变预测。要进一步得到低期望风险，固定允许的神经元分布集合 $\mathcal{M}$ ，并要求训练输出 $\rho_S \in \mathcal{M}$ 满足

$$\mathbb{E}_S \left[\hat{R}_S(f_{\rho_S}) - \inf_{\rho \in \mathcal{M}} \hat{R}_S(f_\rho) \right] \leq \xi_n.$$

对任意固定 $\rho \in \mathcal{M}$ 都有 $\mathbb{E}_S \hat{R}_S(f_\rho) = R(f_\rho)$ 。结合上面的期望泛化差和

¹⁴ S. Mei, A. Montanari, P.-M. Nguyen, *A Mean Field View of the Landscape of Two-Layers Neural Networks* In arXiv preprint arXiv:1804.06561, 2018; S. Mei, T. Misiakiewicz, A. Montanari, *Mean-field Theory of Two-layers Neural Networks: Dimension-free Bounds and Kernel Limit* In arXiv preprint arXiv:1902.06015, 2019

$\mathbb{E}_S \inf_{\rho \in \mathcal{M}} \hat{R}_S(f_\rho) \leq \inf_{\rho \in \mathcal{M}} R(f_\rho)$, 可得

$$0 \leq \mathbb{E}_S R(f_{\rho_S}) - \inf_{\rho \in \mathcal{M}} R(f_\rho) \leq GL_\psi a_n + \xi_n. \quad (8.22)$$

因此, 只要 $a_n \rightarrow 0$ 、 $\xi_n \rightarrow 0$ 且这些速率对允许的数据分布一致成立, 平均场学习器相对于 $\{f_\rho : \rho \in \mathcal{M}\}$ 的超额期望风险便趋于零。由于超额风险非负, Markov 不等式还给出

$$\Pr \left\{ R(f_{\rho_S}) - \inf_{\rho \in \mathcal{M}} R(f_\rho) > \varepsilon \right\} \leq \frac{GL_\psi a_n + \xi_n}{\varepsilon},$$

从而在右侧不超过 δ 时得到相应的 PAC 保证。

上述结论针对分布模型 f_{ρ_S} 。若最终使用有限宽网络 $f_{\rho_{m,S}}$, 还需控制 $\rho_{m,S}$ 逼近 ρ_S 造成的训练与期望风险误差, 并把该项加入式 (8.22) 右侧。只证明神经元数趋于无穷时分布收敛, 尚不能单独推出有限宽网络的泛化。

这里的 ρ 描述一个网络内部的神经元。接下来使用的参数分布描述一组完整网络: 从中抽取一次, 就得到一个完整预测器。这两个对象共享分布语言, 但解决的问题不同, 不能使用同一个分布而不说明含义。

8.5.3 完整网络分布与随机预测器泛化

令学习算法根据样本 S 输出完整网络参数上的分布 Q_S , 再从中抽取参数用于预测。这种随机预测器可以沿两条路线分析。PAC-Bayes 比较 Q_S 与样本独立先验, 给出对训练样本高概率成立的风险界; 分布稳定性则比较相邻样本产生的 Q_S 与 $Q_{S'}$, 控制平均泛化差。相对熵的期望分解还会把前一条路线与互信息联系起来, 但不会使两种概率结论变成同一个结论。

PAC-Bayes 风险界 假设某个训练结果的经验风险很低, 在它附近扰动参数以后, 经验风险仍然很低。这说明训练结果周围存在一组表现相近的网络。PAC-Bayes 方法把这组网络表示为一个数据依赖的参数分布, 并同时计算两项: 随机抽取网络时的经验风险, 以及选择这组网络相对于事先分布需要付出的信息代价。

定义 8.18 PAC-Bayes 的先验与后验 设 Θ 为完整网络的参数空间。先验 P_0 是与样本 S 独立的 Θ 上概率分布, 后验 Q_S 是由 S 决定的 Θ 上概率分布。对于任意分布 Q , 定义

$$\hat{R}_S(Q) = \mathbb{E}_{\theta \sim Q} \hat{R}_S(\theta), \quad R(Q) = \mathbb{E}_{\theta \sim Q} R(\theta).$$

这里的“后验”不要求通过贝叶斯公式计算。上述期望风险评价的是随机预测器: 从 Q 抽取参数, 再用该网络预测。它一般不等于均值参数网络的期

望风险。例如,两个网络的经验错误率分别为 0.02 和 0.10,后验概率为 0.9 和 0.1 时,随机预测器的经验风险为 $0.9 \times 0.02 + 0.1 \times 0.10 = 0.028$ 。若先验对两个网络各赋概率 1/2,相对熵为 $D_{\text{KL}}(Q||P_0) = 0.9 \log 1.8 + 0.1 \log 0.2 \approx 0.368$ 。它量化后验相对于先验重新分配概率质量的程度。

下述定理采用便于完整证明的常数。记 $\text{kl}(a||b) = a \log(a/b) + (1-a) \log((1-a)/(1-b))$ 为 Bernoulli 分布的相对熵,端点按连续延拓解释。

定理 8.19 PAC-Bayes 期望风险界 设损失取值于 $[0, 1]$, $S \sim \mathcal{P}^n$, $n \geq 1$, 先验 P_0 与 S 独立。对于任意 $\delta \in (0, 1)$, 以至少 $1 - \delta$ 的概率, 所有 $Q \ll P_0$ 同时满足

$$\text{kl}(\hat{R}_S(Q)||R(Q)) \leq \frac{D_{\text{KL}}(Q||P_0) + \log((n+1)/\delta)}{n}. \quad (8.23)$$

从而在同一事件上,

$$R(Q) \leq \hat{R}_S(Q) + \sqrt{\frac{D_{\text{KL}}(Q||P_0) + \log((n+1)/\delta)}{2n}}.$$

证明. 固定参数 θ , 记其期望风险为 r 。若单样本损失为 Bernoulli 变量, 经验风险为 k/n 的概率是 $\binom{n}{k} r^k (1-r)^{n-k}$, 故

$$\begin{aligned} & \mathbb{E}_S e^{n \text{kl}(\hat{R}_S(\theta)||r)} \\ &= \sum_{k=0}^n \binom{n}{k} \left(\frac{k}{n}\right)^k \left(1 - \frac{k}{n}\right)^{n-k} \leq n+1. \end{aligned}$$

每一项都是某个二项分布取值于 k 的概率, 因而不超过 1。对一般 $[0, 1]$ 损失, 指数函数与相对熵的凸性允许逐个把损失替换成具有相同均值的 Bernoulli 端点变量, 而不减小指数矩; 因此上界仍然成立。

对独立先验积分, 再使用 Markov 不等式, 以至少 $1 - \delta$ 的概率有

$$\mathbb{E}_{\theta \sim P_0} e^{n \text{kl}(\hat{R}_S(\theta)||R(\theta))} \leq \frac{n+1}{\delta}.$$

在这个只由样本决定的事件上, 对任意 $Q \ll P_0$ 使用换测度不等式

$$\mathbb{E}_Q g \leq D_{\text{KL}}(Q||P_0) + \log \mathbb{E}_{P_0} e^g, \quad (8.24)$$

其推导见式 (7.13)。取 $g(\theta) = n \text{kl}(\hat{R}_S(\theta)||R(\theta))$, 再由 kl 的联合凸性把左侧下界为 $n \text{kl}(\hat{R}_S(Q)||R(Q))$, 即得第一式。最后使用 $\text{kl}(a||b) \geq 2(a-b)^2$ 得到第二式。 ■

Maurer 给出了更精细的指数矩估计, 可把这里的 $n+1$ 改进为相应条件下的 $2\sqrt{n}^{15}$ 。本节保留 $n+1$, 是为了完整展示“固定网络的集中性质

¹⁵ A. Maurer, *A Note on the PAC Bayesian Theorem*, 2004, arXiv: [cs/0411099](https://arxiv.org/abs/cs/0411099)

—对先验积分—同时允许数据依赖后验”的证明过程。定理控制的是泛化差；只有后验的经验风险也小，才能得到低期望风险。如果要证明相对于某个假设空间的 PAC 可学习性，还需说明算法能找到经验风险足够小、且相对熵代价随 n 增长足够缓慢的后验。

样本量的作用可以从定理直接读出。若训练过程能保证 $D_{\text{KL}}(Q_S \| P_0) \leq K$ ，要使经验风险之外的附加项不超过 ε ，一个充分条件是

$$2n\varepsilon^2 \geq K + \log((n+1)/\delta). \quad (8.25)$$

这是含 n 的可检验不等式；忽略 n 的对数项，样本量上界随 $(K + \log(1/\delta))/\varepsilon^2$ 增长。例如，后验的经验风险不超过 0.02，且该附加项不超过 0.03 时，随机预测器的期望风险就以至少 $1 - \delta$ 的概率不超过 0.05。这里的 0.02 与 0.03 只是读界方式的教学数值，不是实际网络的实验结果。

当后验的经验风险恰好为零时，原来的相对熵形式还能给出更强结论。由于 $\text{kl}(0 \| r) = -\log(1 - r)$ ，在同一高概率事件上有

$$R(Q_S) \leq 1 - \exp\left(-\frac{K + \log((n+1)/\delta)}{n}\right) \leq \frac{K + \log((n+1)/\delta)}{n}.$$

此时达到期望风险 ε 的充分条件改为 $n\varepsilon \geq K + \log((n+1)/\delta)$ 。这依赖整个后验的平均经验风险为零，不能由中心参数的分类错误率为零代替。

与范数界相比，PAC-Bayes 把复杂度落实在相对于独立先验的分布选择代价 K 上。参数很多的网络也可能有较小的有效代价，但这种性质需要计算或证明。训练或构造后验时，需要同时减小扰动后的经验风险和相对熵项；只追求参数附近的一大片平坦区域，或者只让后验接近先验，都可能使另一项变差。下面的高斯后验把这种取舍具体写出来。

在连续参数空间中，把 Q 取为单个训练结果上的点质量，通常会使相对熵无穷大。取 $Q = \mathcal{N}(\hat{\theta}, \sigma^2 \mathbf{I})$ 则把训练结果附近的网络一起纳入分析。若 $P_0 = \mathcal{N}(0, \tau^2 \mathbf{I})$ ，参数维度为 p ，则

$$D_{\text{KL}}(Q \| P_0) = \frac{\|\hat{\theta}\|_2^2}{2\tau^2} + \frac{p}{2} \left(\frac{\sigma^2}{\tau^2} - 1 - \log \frac{\sigma^2}{\tau^2} \right). \quad (8.26)$$

较大的低损失邻域允许较分散的后验，但增大后验方差并不总会减小相对熵：方差项在 $\sigma^2 = \tau^2$ 时最小，向任一方向偏离都会增加。这把平坦性变成可检验的经验风险与复杂度权衡。单独测量 Hessian 或极小值的宽度则受参数化影响，不能直接作为泛化保证¹⁶。

图 8.7 固定参数化、方向和坐标尺度，比较相同参数扰动在两个损失谷中引起的经验风险变化。宽谷中的增幅较小，可以说明这一方向的扰动代价较低；要推出泛化保证，仍须同时控制后验经验风险与先验选择代价。重新缩放参数坐标可以改变谷的宽度，所以不能把这张截面的宽窄当作函

¹⁶ L. Dinh, R. Pascanu, S. Bengio, Y. Bengio, *Sharp Minima Can Generalize for Deep Nets* In Proceedings of the 34th International Conference on Machine Learning, 2017, pp. 1019–1028

数本身不变的泛化属性。




图 8.7 同尺度的窄谷与宽谷损失截面。横轴为同一单位方向上的参数位移 s ，即 $\theta = \hat{\theta} + s\mathbf{u}$ 、 $\|\mathbf{u}\|_2 = 1$ 。构造的窄谷与宽谷分别为 $0.1 + 0.45s^2$ 、 $0.1 + 0.08s^2$ ；实心点为谷底，空心点对应相同位移 $s = 0.6$ ，经验风险分别增加 0.162 和 0.0288。两面板共用相同横纵尺度。这是扰动代价的教学示意，不表示宽谷必然具有较小的期望风险。

后验分布的稳定性 PAC-Bayes 比较后验与事先选定的先验。算法稳定性比较的却是两份相邻样本产生的后验。两种比较都用到分布距离，但含义不同：与某个固定先验距离小，不必然意味着替换样本后变化小。

对完整网络分布使用上述配对距离时，如果相邻样本产生的 $Q_S, Q_{S'}$ 可以用较小平均参数距离配对，且损失关于完整参数向量为 Lipschitz，两个随机预测器的平均损失就会接近。

定理 8.20 参数分布稳定性与期望泛化差 设 $S \sim \mathcal{P}^n$ ，随机学习算法输出 $\theta \sim Q_S$ ，损失取值于 $[0, 1]$ ，并关于参数为 L_θ -Lipschitz。若任意替换一条样本所得的 S, S' 都满足 $W_1(Q_S, Q_{S'}) \leq \alpha_n$ ，则

$$\sup_z \left| \mathbb{E}_{Q_S} \ell(\theta, z) - \mathbb{E}_{Q_{S'}} \ell(\theta, z) \right| \leq L_\theta \alpha_n,$$

$$\left| \mathbb{E}_S [R(Q_S) - \hat{R}_S(Q_S)] \right| \leq L_\theta \alpha_n.$$

进一步，若输出参数属于比较空间 Θ ，且

$$\mathbb{E}_S \left[\hat{R}_S(Q_S) - \inf_{\theta \in \Theta} \hat{R}_S(\theta) \right] \leq \rho_n,$$

则 $\mathbb{E}_S R(Q_S) - \inf_{\theta \in \Theta} R(\theta) \leq L_\theta \alpha_n + \rho_n$ 。若这两个速率对所有允许分布一致趋于零，则得到相对于 Θ 的随机 PAC 学习保证。

证明. 对任意配对分布 $\pi \in \Pi(Q_S, Q_{S'})$, 损失期望之差的绝对值不超过

$$\mathbb{E}_\pi |\ell(\theta, z) - \ell(\theta', z)| \leq L_\theta \mathbb{E}_\pi \|\theta - \theta'\|_2.$$

对 π 取下确界得到均匀稳定性, 再由前章的替换样本恒等式得到期望泛化差. 对于任意固定 $\theta \in \Theta$, 近似 ERM 条件给出 $\mathbb{E}_S \hat{R}_S(Q_S) \leq R(\theta) + \rho_n$. 加上泛化差并取下确界即得超额期望风险界. 输出属于 Θ , 所以超额期望风险非负. Markov 不等式给出失败概率至多 $(L_\theta \alpha_n + \rho_n)/\varepsilon$; 令它不超过 δ 即得到 PAC 保证. 这里概率可以同时包含样本和从后验抽取参数的随机性. ■

这个定理直接继承了前章的“稳定性加经验最优性”途径. 如果已有 $W_1(Q_S, Q_{S'}) \leq c/n$ 及 $\rho_n \leq c'/\sqrt{n}$, 则

$$\mathbb{E}_S R(Q_S) - \inf_{\theta \in \Theta} R(\theta) \leq \frac{L_\theta c}{n} + \frac{c'}{\sqrt{n}}.$$

例如, $n \geq \max\{2L_\theta c/\varepsilon, 4(c')^2/\varepsilon^2\}$ 足以使平均超额期望风险不超过 ε . 这里是对给定稳定性和经验最优性速率的条件性推论; 实际神经网络是否具有这些速率, 仍要分析训练过程.

如果难以控制参数距离, 也可以直接控制相邻后验的总变差距离. 对 $[0, 1]$ 损失, 两后验的损失期望之差不超过总变差距离, 并可进一步用 $\sqrt{D_{\text{KL}}(Q_S \| Q_{S'})/2}$ 上界. 这里比较的是 Q_S 与 $Q_{S'}$, 不能替换成 PAC-Bayes 中的 $D_{\text{KL}}(Q_S \| P_0)$ 而省略论证.

相对熵与互信息 两条途径还通过前章的互信息建立联系. 令 $\bar{Q} = \mathbb{E}_S Q_S$ 为算法输出的边缘分布, 令随机输出为 W . 在相关相对熵有限时, 有

$$\mathbb{E}_S D_{\text{KL}}(Q_S \| P_0) = I(W; S) + D_{\text{KL}}(\bar{Q} \| P_0). \quad (8.27)$$

把对数密度比分解成 $\log(dQ_S/d\bar{Q}) + \log(d\bar{Q}/dP_0)$, 再取联合期望即可证明. 第一项表示输出保留了多少当前样本的信息, 第二项表示输出的总体分布偏离所选先验多少. 因此, 先验选择合理时, 平均 PAC-Bayes 代价可以与信息稳定性相联系; 两者给出的概率保证仍然不同, 互信息期望泛化界不能直接当作针对每一份样本的高概率 PAC-Bayes 界.

进一步, 若 $\mathbb{E}_S D_{\text{KL}}(Q_S \| P_0) \leq K_n$, 相对熵非负就给出 $I(W; S) \leq K_n$. 前章定理 7.33 随即推出

$$|\mathbb{E}_S [R(Q_S) - \hat{R}_S(Q_S)]| \leq \sqrt{\frac{K_n}{2n}}.$$

这说明参数分布并不是脱离一般学习理论的另一套保证: 分布包含的样本信息可以控制期望泛化差, 再与经验最优性结合得到期望风险. PAC-Bayes

则进一步提供对样本以高概率成立、允许数据依赖后验的保证；不能把这两种概率结论混为一谈。

两类参数分布的联系与边界 平均场与 PAC-Bayes 都把参数空间上的概率测度作为分析对象，但概率质量所对应的基本单位不同。神经元分布 ρ_S 中的一次抽取只得到一个神经元，完整预测器由式 (8.21) 对全部神经元输出积分得到；PAC-Bayes 后验 Q_S 中的一次抽取则直接得到一个完整网络。因此， f_{ρ_S} 的风险是一个确定性积分模型的风险， $R(Q_S)$ 是对多个完整网络风险再取平均。

两条路线使用的分布距离也承担不同职责。平均场路线中的 $W_1(\rho_S, \rho_{S'})$ 比较相邻训练集产生的神经元群体，用于证明 f_{ρ_S} 的样本稳定性。完整网络分布上的 $W_1(Q_S, Q_{S'})$ 比较随机学习算法对相邻样本的响应，而 PAC-Bayes 中的 $D_{KL}(Q_S \| P_0)$ 比较数据依赖后验与固定先验。前两者服务于稳定性论证，最后一项服务于换测度得到的高概率风险界，其中任何一个较小都不能无条件推出另外两个也较小。

二者可以在更高一层组合，例如令学习算法输出随机的神经元分布，再在这些分布所定义的完整预测器上构造 PAC-Bayes 后验。但这需要另行定义随机对象、先验和损失，并验证相应绝对连续性与可测性条件，不是平均场极限本身的直接结论。本节保留的两条分支因而是两种参数分布参与泛化分析的方式，而不是同一个定理的两种写法。

8.6 理论的比较与使用

前面几节分别从参数大小、参数梯度初始值、参数梯度更新和参数分布出发分析神经网络。这些入口的共同目标，是说明训练算法怎样利用有限样本得到期望风险较低的预测器，但它们观察的对象并不相同。参数大小和初始梯度主要提供函数复杂度或固定特征描述；参数更新分析训练过程怎样选择解；参数分布则进一步区分神经元群体与完整网络随机化。表 8.1 按这四个入口汇总它们怎样接入一般学习理论，不把其中使用的具体工具误列为彼此独立的上位路线。

这些理论没有在同一组条件下给出可以直接排名的误差数值：范数间隔界评价分类错误率，初始梯度特征的 Rademacher 界评价有界 Lipschitz 损失，最小范数回归的精确表达式使用平方损失，PAC-Bayes 的基本结论评价随机预测器。式 (8.11) 还额外付出扰动代价，才将随机预测保证转换为参数中心的保证。比较时应先统一损失、预测器和置信要求，再比较上界。

对同一个训练结果，这些分析可以配合使用。例如，隐式偏差先说明梯度下降为何偏向某类低范数解，范数间隔界再评价该解的分类期望风险；

分析入口	与一般学习理论的联系	期望风险与样本量由什么控制	对训练的指导
参数大小	函数空间复杂度控制泛化; 分层参数变化也可转为损失稳定性	经验间隔错误率、范数与间隔之比、样本量及置信度	同时控制范数与经验间隔, 不能只缩小权重
参数梯度初始值	固定特征接上 RKHS 复杂度、PAC-Bayes 与正则化稳定性	标签与核谱的关系、RKHS 范数、样本量和近似误差	检查初始特征能否以较小范数表达目标
参数梯度更新	动力学确定选解, 再用风险分解、复杂度或稳定性控制泛化	最小范数解的数据依赖风险、归一化间隔、矩阵谱与样本敏感性	检查初始化、损失、参数化和优化器怎样共同选择解
参数分布	神经元分布通过稳定性分析确定积分模型; 完整网络分布通过 PAC-Bayes 或稳定性分析随机预测器	神经元分布变化、有限宽度误差、后验经验风险、相对熵代价与置信度	先区分 ρ 与 Q 的随机单位, 再选择相应距离和泛化结论

表 8.1 神经网络泛化分析的四个入口。每一行对应本章一个上位分析角度; 具体的复杂度界、稳定性定理和 PAC-Bayes 界是连接该角度与期望风险的工具。

如果还能控制样本替换引起的变化, 稳定性会提供另一种保证。若初始梯度特征近似固定, 核方法可以直接控制所选函数的 RKHS 范数, 正则化又能支持稳定性分析; 若特征发生明显变化, 则需要研究实际训练动力学或神经元分布。PAC-Bayes 还可以对训练结果附近的一组网络建立保证, 但得到的是相应后验随机预测器的期望风险。

这些条件可以转化为具体设计。显式范数约束缩小假设空间, 权重衰减在训练目标中加入对大参数的惩罚, 初始化和优化器影响多个解之间的选择, PAC-Bayes 先验则表达在观察当前样本之前对参数的偏好。其中, 先验也可以只用于评价训练后的网络, 并不一定参与训练。它们作用于不同对象, 不能统称为对假设空间的同一种限制。

设计中的困难在于, 较强的约束同时可能排除有用的假设。例如, 减小范数范围可能降低复杂度, 却也可能使原来能够表示的目标函数不再属于比较空间; 此时即便算法达到该空间的最低期望风险, 仍可能留下较大的近似误差。对一个训练方案, 需要分别判断比较空间中是否存在期望风险足够低的假设、算法是否能降低经验风险, 以及所得结果是否满足可验证的泛化条件。前面的理论提供了判断这些问题的工具, 但尚未给出适用于任意任务的网络结构与训练方案选择方法。

样本量的推算也应保留同样的顺序: 确定希望控制哪一种期望风险, 说明经验风险能够降到什么程度, 再求使附加误差足够小的 n 。范数、间隔、稳定性速率和后验复杂度若随 n 变化, 必须一并代入, 不能把它们固定以后得到的缩放关系直接当作所有网络的训练规律。这些理论能够提供可检验的充分条件和训练取舍; 对于仍然空泛的上界, 需要更贴近数据和算法的分析, 而不能把界的大小当成实际测试错误率。

8.7 学习设定扩展的理论边界

前面的理论固定学习问题，再分析训练算法怎样选择期望风险较低的神经网络。规模实验和长时间训练会同时改变比较空间、样本量或优化程度，不能直接套用某个固定问题上的样本复杂度。本节只保留两个与本章主线直接相关的现象：缩放定律考察资源变化与期望损失的经验关系，顿悟考察插值以后训练继续改变选解和泛化的过程。它们用于说明前述复杂度、表示和稳定性分析还缺哪些条件，不构成适用于任意大模型的统一可学习性定理。跨任务学习、长度外推及推理阶段的计算过程会进一步改变任务、目标分布或预测器，分别留给后续范式、模型与系统部分。

8.7.1 缩放定律与能力涌现

在传统样本复杂度分析中，通常先固定假设空间，再讨论增加样本怎样降低估计误差。大语言模型的规模实验同时改变模型、数据和训练计算：更多参数扩大可表示的函数，更多词元补充数据覆盖，更多计算使优化过程继续前进。**缩放定律**（scaling law）记录这些因素与期望损失或测试损失之间的定量关系，常在一定范围内表现为幂律。它的直接用途是根据已有规模实验，预测继续投入资源能够带来多少改进。Kaplan 等报告了语言模型损失随规模变化的近似幂律关系¹⁷。Hoffmann 等进一步研究固定计算预算下模型规模和数据量的分配¹⁸。常用拟合形式为

$$\mathcal{L}(N, D) \approx \mathcal{L}_\infty + aN^{-\alpha} + bD^{-\beta}, \quad (8.28)$$

其中 N 为参数量， D 为训练词元数， $a, b, \alpha, \beta > 0$ 由实验拟合。 $\mathcal{L}_\infty$ 是拟合模型中的极限项，不能未经论证认定为数据分布的贝叶斯风险。固定数据量时，参数量翻倍使模型规模项变为原来的 $2^{-\alpha}$ 倍。

这一关系不同于前面的 PAC 界。PAC 界在假设成立时控制随机样本带来的失败概率；经验缩放定律描述特定模型族、数据和训练配方中的平均趋势，没有自动附带分布无关的概率保证。它仍可用于预算规划，但结论应明确以拟合形式为前提。

定理 8.21 幂律模型下的计算预算分配 把式 (8.28) 的右侧作为精确的规划目标，并将 N, D 视为正实数。若训练计算量为 $C = \kappa ND$ ，其中 $\kappa > 0$ 固定，则最优分配满足

$$\alpha a N^{-\alpha} = \beta b D^{-\beta}, \quad N \propto C^{\beta/(\alpha+\beta)}, \quad D \propto C^{\alpha/(\alpha+\beta)}. \quad (8.29)$$

证明. 代入 $D = C/(\kappa N)$ ，并令 $v = \log N$ ，去掉常数项后的目标为 $ae^{-\alpha v} + b(\kappa/C)^{\beta} e^{\beta v}$ 。它关于 v 严格凸且在两端趋于无穷，故唯一驻点为全局最小点。令一阶导数为零即得两项边际收益相等的条件；再与 $ND = C/\kappa$ 联立，

¹⁷ J. Kaplan, S. McCandlish, T. Henighan, T. B. Brown, B. Chess, R. Child, S. Gray, A. Radford, J. Wu, D. Amodei, *Scaling Laws for Neural Language Models* In arXiv preprint arXiv:2001.08361, 2020

¹⁸ J. Hoffmann, S. Borgeaud, A. Mensch, et al., *Training Compute-Optimal Large Language Models* In arXiv preprint arXiv:2203.15556, 2022

得到两种规模关于 C 的幂次。 ■

理论模型可以解释某些幂律的来源，而不是只拟合曲线。例如，设目标函数在一组正交特征上的平方系数满足 $c_j^2 \asymp j^{-1-\alpha}$ ，并假定学习过程已经准确学会前 m 个方向，则尚未学会的平方误差为

$$\sum_{j>m} c_j^2 \asymp \int_m^\infty u^{-1-\alpha} du = \frac{1}{\alpha} m^{-\alpha}.$$

如果可学会的方向数随计算量按 $m \asymp C^r$ 增长，就得到 $C^{-r\alpha}$ 型误差下降。这说明特征谱与学习动力学如何共同产生指数；结论依赖正交分解与学习次序等假设。Bordelon 等在可求解的随机特征模型中分析了宽度、训练时间与数据规模的缩放关系¹⁹。这些结果提供机制模型，并没有证明真实语言模型必须服从同一个指数。

同样的幂律还可以来自不同频率知识的逐步覆盖。设第 j 类知识在测试中的出现概率为 $p_j \asymp j^{-s}$ ，其中 $s > 1$ 。在一个教学模型中，若学习者已经掌握前 m 类知识，其余类别仍然预测错误，零一损失下的期望风险就是未掌握类别的总概率：

$$R_m = \sum_{j>m} p_j \asymp m^{1-s}.$$

模型逐步学会较少见的知识时，总体错误率便可能平滑地按幂律下降。Michaud 等的知识单元模型沿这一方向解释缩放与能力变化；其中的“量化”指知识由离散单元组成的假设，不是把模型参数从浮点数压缩为整数²⁰。上述教学模型说明了一种可能机制，不能证明自然语言知识确实可以独立地分成这些类别。

特征本身也可能在规模增长和训练过程中发生变化。如果网络学会了更适合任务的表示，它面对的有效谱结构就不再等于初始化时的谱结构。Bordelon 等在 2025 年的可求解模型中发现，对于初始核难以有效表示的目标，特征学习可以改善关于训练时间和计算量的缩放指数；这种改进并非对所有任务都成立²¹。

一个简单的表示问题可以帮助理解这种差别。设输入为 $(x_1, x_2) \in [-1, 1]^2$ ，目标是预测 $x_1 x_2$ 。如果模型只能使用 x_1, x_2 的线性组合，无论增加多少数据，都不能在整个输入区域上准确表示这个目标；若训练形成了乘积特征 $x_1 x_2$ ，后续线性预测就能够表示它。这个例子不推导某个缩放指数，但说明了两种改进的区别：在固定表示中增加资源，仍受到原有近似误差的限制；学习新特征则可能改变这种限制。

Defilippis 等在 2026 年进一步研究了二次网络与对角网络，把超额期望风险的缩放区间与权重谱、样本规模及权重衰减联系起来²²。这些结果解释了为何缩放指数可能随学习状态改变，也把缩放研究与前面的 NTK、参数大小及特征分布理论连接起来。

¹⁹ B. Bordelon, A. Atanasov, C. Pehlevan, *A Dynamical Model of Neural Scaling Laws* In arXiv preprint arXiv:2402.01092, 2024

²⁰ E. J. Michaud, Z. Liu, U. Girit, M. Tegmark, *The Quantization Model of Neural Scaling* In Advances in Neural Information Processing Systems, 2023

²¹ B. Bordelon, A. Atanasov, C. Pehlevan, *How Feature Learning Can Improve Neural Scaling Laws* In International Conference on Learning Representations, 2025

²² L. Defilippis, Y. Xu, J. Girardin, V. Erba, E. Troiani, L. Zdeborová, B. Loureiro, F. Krzakala, *Scaling Laws and Spectra of Shallow Neural Networks in the Feature Learning Regime* In International Conference on Learning Representations, 2026

因此，现有研究尚未给出适用于所有大模型的统一缩放机制。较明确的认识是：误差中尚未解决的部分具有怎样的分布，以及学习过程随资源增加能够解决其中多少部分，共同决定了宏观曲线。固定特征的谱尾、不同频率的知识单元和持续变化的特征表示，可以产生相似的幂律，也可以产生不同的指数或平台。即使损失与资源在双对数坐标下近似呈直线，也不足以在这些机制之间作出选择；还需要改变数据组成、训练时间或特征学习程度，检验理论对新实验的预测。

平均负对数似然的平滑下降也不必表现为任务正确率的平滑变化。若一道题包含 q 个独立子步骤，每步正确率为 p ，整题正确率为 p^q 。取 $q = 10$ ， p 从 0.8 增至 0.9 时，整题正确率从约 0.107 增至 0.349；再以是否超过 0.3 判断“具备能力”，指标就出现跳变。Schaeffer 等指出，一些被称为能力涌现的现象可以由评价指标的非线性产生²³。这个例子不证明所有跃迁都是测量效应；它说明连续损失、任务指标与所声称的机制需要分别检验。

资源增长还可能使先前缺失的计算结构变得可实现或可被优化学到。例如，完成一道多步题可能同时需要检索事实、保存中间结果和执行一个变换，只有这些部分都足够可靠时，整题正确率才明显提高。这是能力组合产生阈值的一种解释，与评价指标的阈值效应并不相同。要声称模型涌现了新机制，需要进一步识别这种结构，并通过干预验证它对结果的作用。下一小节的顿悟提供了一个更容易控制变量的研究场景：保持模型规模不变，只观察训练时间如何改变内部结构与泛化。

8.7.2 顿悟与泛化的突然改善

规模之外，训练时间也可能改变泛化行为。在一些算法任务中，模型很早就把样本全部分对，测试错误率却长期很高；继续训练很久后，测试错误率才明显下降。这种经验分类错误率很早下降、测试错误率却在较晚阶段突然改善的现象，称为**顿悟**（grokking），这里特指训练中延迟出现、在测试曲线上较为突然的泛化改善。Power 等在小规模算法数据集上系统展示了这一现象²⁴。例如，模加法任务要求根据 (a, b) 预测 $(a + b) \bmod q$ 。记住训练中出现的配对即可获得低经验风险，而在未见配对上正确预测，需要学习可复用的算术结构。图 8.8 把经验分类错误率与测试错误率下降的两个阶段分开表示。

模加法给出了比“模型后来学会了规律”更具体的解释。Nanda 等分析了小型 Transformer，发现网络可以使用周期特征表示数字，再通过类似三角恒等式的计算组合两个输入，形成能够复用于未见配对的计算结构²⁵。例如，令 $\omega = 2\pi/q$ ，把数字 a 表示成 $(\cos \omega a, \sin \omega a)$ ，就有

$$\cos(\omega(a + b)) = \cos(\omega a) \cos(\omega b) - \sin(\omega a) \sin(\omega b).$$

这个关系对所有 a, b 成立，不需要为每个训练配对单独存储答案。与记忆

²³ R. Schaeffer, B. Miranda, S. Koyejo, *Are Emergent Abilities of Large Language Models a Mirage?* In *Advances in Neural Information Processing Systems* 36, 2023

²⁴ A. Power, Y. Burda, H. Edwards, I. Babuschkin, V. Misra, *Grokking: Generalization Beyond Overfitting on Small Algorithmic Datasets* In arXiv preprint arXiv:2201.02177, 2022

²⁵ N. Nanda, L. Chan, T. Lieberum, J. Smith, J. Steinhardt, *Progress Measures for Grokking via Mechanistic Interpretability* In *International Conference on Learning Representations*, 2023




图 8.8 顿悟的定性示意。零一损失下的经验风险先接近零，测试错误率经过较长训练后才下降。竖线 t_{fit} 、 t_{gen} 分别标记训练分类拟合和测试错误率随后下降的阶段。横轴表示训练进程，曲线用于解释时间上的分离，不来自实验测量。训练目标的交叉熵在经验分类错误率接近零以后仍可能继续下降。

训练表相比，学会这种可复用的运算更有可能预测未见配对。这里用一个频率解释周期表示的直觉，实际网络的分析还要检查所用频率、输出计算和消融结果，不能只凭发现周期特征就认定网络完整实现了目标算法。

整个过程中参数数量不变，因此仅看参数计数无法解释这种时间变化。可能改变的是特征表示、不同解之间的相对偏好，以及训练结果能够被多简单地描述。Kumar 等在特定模型中把顿悟解释为从惰性训练向显著特征学习的转变²⁶。如果初始化时的特征不适合目标问题，而后续训练逐渐形成有用特征，那么固定 NTK 近似就遗漏了促成后期泛化改善的变化。

这一解释有适用范围。Levi 等在线性估计模型中也构造了延迟泛化现象²⁷。因而仅观察到训练与测试曲线在时间上分离，不能证明发生了特征学习，也不能据此断言 NTK 必然失效。要检验固定核解释是否充分，需要观察特征或核是否明显变化，并比较相同任务上固定特征模型的行为。

即使确认发生了特征学习，测试曲线的突然下降也未必意味着参数或内部机制瞬间突变。通用计算结构可能已经逐步增强，但早期预测仍由记忆样本的结构主导；当二者的相对作用发生变化时，分类正确率才集中改善。因此，研究顿悟除了记录经验风险与测试错误率，还需要跟踪能够反映计算结构变化的量。

隐式偏差提供了另一条机制线索：插值以后，优化仍可能逐渐偏向结构更简单或归一化间隔更大的解。如果使用权重衰减，这部分作用属于显式正则化，需要与优化器自身的隐式偏差区分。DeMoss 等从描述复杂度和有损压缩角度研究顿悟中的复杂度演化，为“先拟合、后形成更可压缩结

²⁶ T. Kumar, B. Bordelon, S. J. Gershman, C. Pehlevan, *Grokking as the Transition from Lazy to Rich Training Dynamics In International Conference on Learning Representations*, 2024

²⁷ N. Levi, A. Beck, Y. Bar-Sinai, *Grokking in Linear Estimators—A Solvable Model that Groks without Understanding In International Conference on Learning Representations*, 2024

构”的解释提供了具体分析²⁸。。

PAC-Bayes 可以把这类解释转化为需要验证的量。对每个训练时刻构造后验 Q_t ，检查扰动后的经验风险 $\hat{R}_S(Q_t)$ 以及相对于同一个独立先验的 $D_{KL}(Q_t||P_0)$ 。如果后期同时保持较低经验风险并降低有效复杂度，定理 8.19 的期望风险上界就会改善。定理同时适用于所有后验，因此允许沿训练轨迹比较。这里给出的是一种可检验的分析方式，顿悟曲线本身并不保证相对熵必然下降，也没有证明所有顿悟都由同一种压缩机制产生。

与稳定性的联系也需要单独验证。前章某些非凸 SGD 上界随迭代次数增加而变松，只是这种最坏情形估计无法捕捉后期改善，并不证明实际算法越来越不稳定。若特征重组以后损失对样本替换更不敏感，平均稳定性或参数分布稳定性可能给出更合适的解释，但需要实际控制相应变化。顿悟主要在受控算法任务中得到清楚展示，既不是 Transformer 独有的现象，也不能直接当作大语言模型所有推理能力出现的机制。

8.8 本章小结

过参数化网络为何仍可能泛化，不能由参数数量单独回答。可学习性保证还要说明训练算法选出了什么函数，并控制该函数的复杂度或对样本的敏感性，同时保留数据分布与近似能力条件。参数数量仍能进入 VC 维上界，为整个固定架构提供统计保证；要解释某个训练结果为何具有较小的期望风险，通常还需要比网络空间最坏情形更具体的选解条件。

本章四种分析分别抓住这种选择的不同方面。参数大小通过范数与间隔限制有效函数空间；参数梯度初始值在适当的惰性训练条件下确定核特征，使 RKHS 范数与核谱可以用于分析；参数梯度更新决定算法在许多经验最优解之间偏向哪一个；参数分布则用后验相对先验的偏离程度评价随机预测的复杂度。每一种分析都还要连接经验风险、近似能力和样本量，才能成为完整的学习保证。核矩阵正定不等于必然泛化，最大间隔与最小范数结论也都有对应的模型、初始化和损失条件。

这些因素与上一章的稳定性存在具体联系，却不能直接互相替代。参数范数影响损失对参数变化的敏感程度，梯度动力学影响替换观测后的参数差异，参数分布则可以通过分布距离或信息量联系期望泛化差。训练过程中参数移动较小，与替换一个训练观测后算法输出变化较小，是两个不同的比较。只有把这种比较和经验优化误差都控制住，才可沿稳定性途径得到可学习性；复杂度与 PAC-Bayes 也可独立提供其他充分途径。

缩放定律同时改变模型、数据与训练计算，顿悟则在模型规模不变时考察训练继续进行后选解和泛化怎样变化。二者都能提示需要解释的机制，却不动自动给出固定学习问题上的 PAC 保证。若训练分布与评价分布进一步发生变化，还须说明源域信息为何能够支持目标域预测，这将成为下一

²⁸ B. DeMoss, S. Sapora, J. Foerster, N. Hawes, I. Posner, *The Complexity Dynamics of Grokking In Physica D: Nonlinear Phenomena*, 2025, vol. 482, pp. 134859

章迁移学习理论的中心问题。

延伸阅读 范数方向可阅读 Bartlett、Foster 与 Telgarsky 的谱归一化间隔分析，重点跟踪各层范数与分类间隔如何一起出现。这样可以看清为什么单独缩小权重，或单独报告参数数量，都不足以判断分类期望风险²⁹。。

梯度特征方向可继续阅读 Arora 等对过参数化两层网络的分析，理解核矩阵、标签方向与优化速度和期望风险如何联系。梯度更新方向则可阅读 Soudry 等关于可分数据的研究，对照参数范数不断增大与方向趋向最大间隔解为何并不矛盾³⁰。。

若要补全参数分布路线中的概率工具，可阅读 Maurer 对 PAC-Bayes 不等式的推导，核对本章换测度步骤与指数矩估计的依据³¹。。

若继续研究矩阵分解，可用 Razin 与 Cohen 的反例检查隐式正则化的边界：训练动力学的偏好未必能由某个固定矩阵范数完整表达³²。。

²⁹ P. L. Bartlett, D. J. Foster, M. J. Telgarsky, *Spectrally-Normalized Margin Bounds for Neural Networks* In *Advances in Neural Information Processing Systems* 30, 2017

³⁰ S. Arora, S. S. Du, W. Hu, Z. Li, R. Wang, *Fine-Grained Analysis of Optimization and Generalization for Overparameterized Two-Layer Neural Networks* In *Proceedings of the 36th International Conference on Machine Learning*, 2019, pp. 322–332; D. Soudry, E. Hoffer, M. S. Nacson, S. Gunasekar, N. Srebro, *The Implicit Bias of Gradient Descent on Separable Data* In *Journal of Machine Learning Research*, 2018, vol. 19, no. 70, pp. 1–57

³¹ A. Maurer, *A Note on the PAC Bayesian Theorem*, 2004, arXiv: [cs/0411099](https://arxiv.org/abs/cs/0411099)

³² N. Razin, N. Cohen, *Implicit Regularization in Deep Learning May Not Be Explainable by Norms* In *Advances in Neural Information Processing Systems*, 2020

迁移学习的可学习性

一个邮件分类器在过去几个月的邮件上取得了较小的经验风险。此前各章讨论了怎样控制假设空间或学习算法，使这个结果能够说明它在同一数据分布下的期望风险。部署到新的月份后，问题又多了一层：新月份的邮件可能具有不同的输入分布，同一输入对应的标签也可能改变。即使源域样本已经足够多，原有的泛化保证也未必适用于目标域。

迁移学习理论需要同时回答两个问题。已有观测是否包含判断目标域标签所需的信息；如果包含，需要多少样本才能把这些信息转化为可靠的预测。前一个问题取决于源域与目标域保留了什么联系，后一个问题还取决于假设空间和学习算法的复杂度。VC 维、参数范数、参数分布和算法稳定性仍然有用，但它们必须与跨域条件结合，才能支持目标域期望风险的保证。

为把信息是否足够与有限样本能否估计分开，第 9.1 节先固定数据、评价目标与允许的分布变化；其中的反例给出后续保证必须跨过的可识别性门槛。目标域输入可用时，第 9.2 节把跨域风险连接与复杂度或稳定性控制结合起来。训练阶段连目标域输入也不可用时，第 9.3 节分别在共享标签机制和环境抽样两类条件下建立保证。第 9.4 节再用预训练表示、持续偏移和有限监督说明这些条件会怎样改变，以及哪些条件仍缺少可验证的证据。

9.1 迁移学习的学习问题

9.1.1 数据与评价目标

迁移学习（transfer learning）利用已有领域或任务中的信息帮助新的学习问题。本章主要研究输入空间 X 与标签空间 Y 保持相同、数据分布发生变化的情形。提供已有数据的环境称为**源域**（source domain），最终需要作出预测的环境称为**目标域**（target domain）。例如，过去月份的邮件来自源域，即将处理的新月份邮件来自目标域。

记源域与目标域的联合分布分别为 $\mathcal{P}_S$ 和 $\mathcal{P}_T$ ，它们都定义在 $X \times Y$ 上。

固定假设空间 $\mathcal{H}$ 与取值在 $[0, 1]$ 中的损失函数 ℓ 。同一个假设 h 在两域上的期望风险分别为

$$R_S(h) = \mathbb{E}_{\mathcal{P}_S} \ell(h(x), y), \quad R_T(h) = \mathbb{E}_{\mathcal{P}_T} \ell(h(x), y). \quad (9.1)$$

这里 R_S 与 R_T 的下标分别标明源域与目标域；有帽号的 $\hat{R}$ 才表示经验风险。后文用 $\mathcal{P}_D^X$ 表示域 D 的输入边缘分布，以免把域的标记与输入的标记混淆。本章默认损失及涉及的上确界具有所需的可测性，各随机抽样过程均定义良好。

目标域期望风险 $R_T(h)$ 才是部署时要控制的量。其比较基准通常为 $R_{T, \mathcal{H}}^* = \inf_{h \in \mathcal{H}} R_T(h)$ ，即同一假设空间在目标域能够达到的最低期望风险。差值 $R_T(h) - R_{T, \mathcal{H}}^*$ 称为 **目标域超额期望风险** (target-domain excess risk)。这个基准可能大于零；可学习性要求学到接近基准的假设，并不要求消除输入信息不足带来的全部错误。

理论结论还取决于算法能够观察什么。**领域自适应** (domain adaptation) 允许在学习阶段使用目标域样本。本章重点分析无监督领域自适应：算法收到带标签的源域样本 S_S 与无标签的目标域样本 U_T ，其中

$$S_S \sim \mathcal{P}_S^{n_S}, \quad U_T \sim (\mathcal{P}_T^X)^{n_T},$$

两批样本相互独立， $\mathcal{P}_T^X$ 表示只保留输入的目标域边缘分布。若能够取得足够多的目标域标签，直接在目标域应用前几章的 PAC 理论便可得到学习保证；迁移理论进一步研究源域信息能否减少对目标域标签的需求。

领域泛化 (domain generalization) 在训练与模型选择阶段不使用目标域样本。算法只能使用若干训练环境的带标签样本，再把学到的假设用于未见环境。预测时读入一个新输入是必要的；这里排除的是利用目标域样本更新假设或选择模型。缺少目标域数据后，需要更明确地规定哪些新环境属于允许的评价范围。

为了区分算法可见的信息、评价对象和概率来源，还需把这两类问题细分为三种设定。领域自适应固定一组源域与目标域，算法观察源域带标签样本 S_S 和目标域无标签输入 U_T ，输出用于该目标域的假设。评价对象是目标域风险 R_T ，比较基准是 $R_{T, \mathcal{H}}^*$ ，保证中的概率来自两批样本和算法随机性。

逐目标域领域泛化 (target-wise domain generalization) 固定训练域组，并把一个允许的目标域作为外层量词给定。算法只能观察训练域的带标签样本，输出不能针对该目标域重新选择；每个目标域上的评价风险和比较基准仍分别是 R_T 与 $R_{T, \mathcal{H}}^*$ 。此时保证中的概率来自训练域样本和算法随机性，目标域本身不在该概率中平均。

环境平均领域泛化 (environment-average domain generalization) 则先规

定环境分布 $\mathcal{Q}$ ，从中抽取 K 个训练环境，并在每个环境内取得一个数据块。算法输出用于未来随机环境的共同假设，评价风险为 $R_{\mathcal{Q}}(h) = \mathbb{E}_{p \sim \mathcal{Q}} R_p(h)$ ，比较基准是 $\inf_{h \in \mathcal{H}} R_{\mathcal{Q}}(h)$ 。相应概率同时包含环境抽样、环境内抽样和算法随机性。三种设定沿用同一损失、输出范围、可测性和计算层次，但分布对象、可见信息、比较基准与概率来源不同。

9.1.2 分布偏移与可识别性

源域与目标域的联系可以通过联合分布的分解来描述。若两个域中同一输入的标签规律不变，源域标签仍能提供相关信息；若标签规律也可以任意改变，再多源域样本也不能说明目标域应当如何分类。下面的设定指出哪些部分允许变化，哪些部分被假定保留。为避免在源域从未出现的输入上比较任意选取的条件概率版本，协变量偏移还需与后文的覆盖条件结合使用。

定义 9.1 协变量偏移 若存在一个条件标签分布 $K(dy | x)$ ，使得

$$\mathcal{P}_D(dx, dy) = \mathcal{P}_D^X(dx)K(dy | x), \quad D \in \{S, T\},$$

则称两域满足协变量偏移设定。该设定允许 $\mathcal{P}_S^X$ 与 $\mathcal{P}_T^X$ 不同。

协变量偏移 (covariate shift) 保留给定输入后的标签分布。例如，目标域的长邮件更多，但在长邮件内部、短邮件内部，诈骗比例分别保持不变。若一个分类器在长邮件上更容易出错，长邮件比例增加仍会提高它的目标域期望风险；条件标签分布不变并不意味着两个期望风险相同。

定义 9.2 标签偏移 若存在条件输入分布 $K(dx | y)$ ，使得

$$\mathcal{P}_D(dx, dy) = \mathcal{P}_D^Y(dy)K(dx | y), \quad D \in \{S, T\},$$

则称两域满足标签偏移设定。该设定允许 $\mathcal{P}_S^Y$ 与 $\mathcal{P}_T^Y$ 不同。

标签偏移 (label shift) 保留每个类别内部的输入分布。例如，诈骗邮件的总体比例增加，但诈骗邮件内部的特征分布不变，正常邮件内部的特征分布也不变。类别比例的改变通常会同时改变给定输入后的类别概率，所以标签偏移与协变量偏移是不同的假设。

概念偏移 (concept shift) 指给定输入后的标签分布发生变化，也称条件偏移。例如，源域长邮件中的诈骗比例为 0.1，目标域却变为 0.4，即使长邮件本身的出现频率不变，源域标签也不能直接代表目标域标签。本章比较条件分布时，均在两域共同覆盖的输入区域上理解这种变化；若目标域出现源域完全未覆盖的输入，还存在额外的信息缺失。

图 9.1 对比了这些变化发生的位置。图中的区别说明跨域假设保留了哪一部分信息，并不单独构成可学习性结论。例如，协变量偏移没有规定目标域是否包含源域从未出现的输入；标签偏移也没有保证仅凭无标签输入就能确定新的类别比例。




图 9.1 分布偏移改变联合分布的不同组成部分。实线表示源域，虚线表示目标域；密度、类别比例和条件概率均为规范化的教学构造，不表示实测频率。协变量偏移允许输入分布改变，标签偏移允许类别比例改变，概念偏移则改变给定输入后的标签分布，图中 $\eta(x) = \mathbb{P}(y = 1 | x)$ 。这些设定还需与覆盖条件或其他可识别条件结合，才能支持迁移保证。

输入密度如何变化,与目标输入能否在源域中出现,是两个问题。图 9.2 用同一坐标尺度比较三种覆盖程度。目标域的支持完全位于源域支持内时,每个目标区域原则上都能获得源域观测；部分或几乎全部目标区域没有源域概率时,在这些区域重复增加源域样本也不能补上标签信息。即使完全覆盖,源域概率过小仍会造成后文密度比过大的困难。




图 9.2 同尺度的三种支持覆盖。源密度均为 $[1, 4]$ 上的 $1/3$ ，目标密度均为长度 2 区间上的 $1/2$ ；(a)、(b)、(c) 的目标支持依次为 $[1.5, 3.5]$ 、 $[3, 5]$ 、 $[3.9, 5.9]$ 。深色区域没有源密度，其目标概率 $u_T = \mathbb{P}_T\{p_S(X) = 0\}$ 依次为 0、0.5、0.95。实线、虚线与底色共同区分源域、目标域；只有 (a) 满足覆盖条件 $p_T(x) > 0 \Rightarrow p_S(x) > 0$ 。密度为规范化教学构造，不是实验分布。

图 9.3 给出更直接的边界：即使输入分布相同，两种相反的目标标签规律也能产生相同的可观察数据。仅使表示或输入分布接近，不能自动建立迁移保证。

这里需要区分“样本还不够多”与“现有类型的数据没有提供答案”。如果两种可能的目标域标签规律产生完全相同的可观察数据，算法就无法判断当前是哪一种规律。我们把能否由可观察分布区分所需预测规律的问题称为**可识别性**（identifiability）问题。下面的定理把这种困难与假设空间大小分开。




图 9.3 相同可观察数据不能区分两种目标规律。两域都以概率 $1/2$ 产生输入 0 或 1，源标签为 $y = x$ 。算法只收到左侧带标签源样本和无标签目标输入，目标标签并未提供；右侧两种可能分别取 $y = x$ 与 $y = 1 - x$ 。固定算法内部随机数后，两种情形必得到同一输出。图中以 $h(x) = x$ 为例，勾、叉逐点对照同一预测与隐藏标签：零一损失下，源风险为 0，两种目标风险分别为 0、1。任意二分类输出在这两种目标规律下的风险之和为 1。输入完全对齐仍未提供选择目标规律的证据，还需目标标签或连接两域标签规律的额外条件。

定理 9.3 缺少覆盖时的不可学习性 采用二分类零一损失。令 $X = \{a, b\}$ 、 $Y = \{0, 1\}$ ，且 $\mathcal{H} = \{h_0, h_1\}$ 满足

$$h_0(a) = h_1(a) = 0, \quad h_0(b) = 0, \quad h_1(b) = 1.$$

源域恒产生 $(a, 0)$ ，目标域输入恒为 b 。允许的两个目标域分别令 b 的标签恒为 0 或恒为 1。对任意只使用带标签源域样本与无标签目标域样本、输出属于 $\mathcal{H}$ 的可能随机化学习算法 A ，无论两类样本量多大，总有一个允许的目标域满足

$$\mathbb{P}_{S_S, U_T, A} \left(R_T(A(S_S, U_T)) > \frac{1}{4} \right) \geq \frac{1}{2}.$$

这里概率包含抽样与算法内部的随机性。两个设定各自都存在源域与目标域期望风险同时为零的假设。

证明. 两种设定中，算法收到的全部源域样本都是 $(a, 0)$ ，全部目标域输入都是 b ，因此输入数据的分布完全相同。设算法输出 h_1 的概率为 p ；这个概率只可能来自算法内部随机性，且在两个设定中相同。目标标签为 0 时，算法以概率 p 输出 h_1 ，其目标域零一风险为 1；目标标签为 1 时，算

法以概率 $1 - p$ 输出 h_0 ，其目标域零一风险也为 1。两者至少有一个不小于 $1/2$ 。标签为 0 的设定中 h_0 在两域均无错误，标签为 1 的设定中 h_1 在两域均无错误，故失败并非假设空间缺少合适的假设。 ■

这个假设空间只有两个假设，VC 维为 1。减少参数数量、限制参数大小，甚至允许无限源域样本，都不能确定 b 的目标标签。反例也符合共享条件标签机制的描述：每种设定都可把同一标签规律定义在 $\{a, b\}$ 上，但源域永远不提供 b 的信息。迁移学习的不可学习性研究因此需要同时检查分布联系与可观察数据，而不能只检查假设空间复杂度¹。

¹ S. Ben-David, T. Lu, T. Luu, D. Pál, *Impossibility Theorems for Domain Adaptation* In Proceedings of the Thirteenth International Conference on Artificial Intelligence and Statistics, 2010, pp. 129–136

9.1.3 迁移学习的 PAC 要求

前面的反例要求我们明确“对哪些分布保证学习成功”。记 $\mathfrak{P}_{\text{DA}}$ 为允许的源域、目标域联合分布对组成的集合。共享条件标签机制、输入覆盖程度以及算法已知的分布信息，都应当写入问题设定。改变这些条件，可能改变同一个假设空间的可学习性。

定义 9.4 相对于分布族的领域自适应 PAC 可学习性 固定 $\mathcal{H}$ 、损失函数 ℓ 及允许的分布对集合 $\mathfrak{P}_{\text{DA}}$ 。若存在取值于 $\mathcal{H}$ 的学习算法 A 与有限的样本量函数 m_S, m_T ，使得对任意 $\varepsilon, \delta \in (0, 1)$ 、任意 $(\mathcal{P}_S, \mathcal{P}_T) \in \mathfrak{P}_{\text{DA}}$ ，以及 $n_S \geq m_S(\varepsilon, \delta)$ 、 $n_T \geq m_T(\varepsilon, \delta)$ ，都有

$$\mathbb{P}_{S_S, U_T, A} \left(R_T(A(S_S, U_T)) - R_{T, \mathcal{H}}^* \leq \varepsilon \right) \geq 1 - \delta,$$

则称 $\mathcal{H}$ 在该设定下是领域自适应 PAC 可学习的。样本量函数可以依赖 $\mathcal{H}$ 及 $\mathfrak{P}_{\text{DA}}$ 的统一参数，但不能依赖其中未知的具体分布对。

这里采用输出属于 $\mathcal{H}$ 的学习要求，并允许不可知设定，即 $R_{T, \mathcal{H}}^*$ 不必为零。若问题还给出已知的密度比等辅助信息，应把这些信息作为算法的额外输入。定义只要求统计上的可学习性，寻找满足要求的假设是否能够高效完成，是另一个问题。

定义 9.5 逐目标域领域泛化 PAC 可学习性 设 $\mathfrak{P}_{\text{DG}}$ 是允许训练域组 $\mathcal{D} = (\mathcal{P}_1, \dots, \mathcal{P}_K)$ 的集合，并为每个 $\mathcal{D}$ 指定允许目标域集合 $\mathcal{T}(\mathcal{D})$ 。记训练域均匀混合为 $\bar{\mathcal{P}}_{\mathcal{D}} = K^{-1} \sum_{e=1}^K \mathcal{P}_e$ 。若存在取值于 $\mathcal{H}$ 的算法 A 和有限样本量函数 m ，使对任意 $\varepsilon, \delta \in (0, 1)$ 、任意 $\mathcal{D} \in \mathfrak{P}_{\text{DG}}$ 、任意固定的 $\mathcal{P}_T \in \mathcal{T}(\mathcal{D})$ 及任意 $n \geq m(\varepsilon, \delta)$ ，都有

$$\mathbb{P}_{S \sim \bar{\mathcal{P}}_{\mathcal{D}}, A} \left(R_T(A(S)) - R_{T, \mathcal{H}}^* \leq \varepsilon \right) \geq 1 - \delta,$$

则称 $\mathcal{H}$ 在该设定下是逐目标域领域泛化 (target-wise domain gener-

alization) PAC 可学习的。算法在训练和模型选择时不接收目标域样本；目标域由概率之外的全称量词固定。

这个定义要求同一个算法与样本量门槛适用于每个允许目标域，但每个目标域可以对应不同的高概率事件。若一个结论用同一个训练样本事件同时控制全部允许目标域，它比逐目标域定义要求更强。

定义 9.6 环境平均领域泛化 PAC 可学习性 设 $\mathfrak{M}$ 是允许的环境分布族，其中每个 $Q \in \mathfrak{M}$ 都是 Z 上概率分布的分布。训练时先独立抽取 $\mathcal{P}_1, \dots, \mathcal{P}_K \sim Q$ ，再从每个环境抽取数据块 $D_e \sim \mathcal{P}_e^n$ ，算法只接收 $S = (D_1, \dots, D_K)$ 。定义

$$R_Q(h) = \mathbb{E}_{\mathcal{P} \sim Q} R_{\mathcal{P}}(h).$$

若存在取值于 $\mathcal{H}$ 的算法 A 以及有限的环境数门槛 k_0 和总观测数门槛 m_0 ，使对任意 $\varepsilon, \delta \in (0, 1)$ 、任意 $Q \in \mathfrak{M}$ ，只要 $K \geq k_0(\varepsilon, \delta)$ 且 $Kn \geq m_0(\varepsilon, \delta)$ ，就有

$$\mathbb{P}_{\mathcal{P}_1, \dots, \mathcal{P}_K, D_1, \dots, D_K, A} \left(R_Q(A(S)) - \inf_{h \in \mathcal{H}} R_Q(h) \leq \varepsilon \right) \geq 1 - \delta,$$

则称 $\mathcal{H}$ 在该设定下是**环境平均领域泛化** (environment-average domain generalization) PAC 可学习的。

环境平均保证的概率包含训练环境、环境内观测和算法随机性；未来环境已经在 R_Q 中取平均。比较基准是同一个假设在环境分布上的最低平均风险，而不是允许每个环境分别选择最优假设后再取平均。只有当相应超额期望风险能够随两层样本量增加而任意减小时，才能得到定义 9.6 中的 PAC 可学习性。

三种设定都要求先说明允许的分布族。一个上界若始终保留正的分布偏移项，仍可揭示目标域表现受哪些因素影响，却不能直接证明任意精度的 PAC 学习。下面的定理将分别注明它支持领域自适应、逐目标域领域泛化还是环境平均领域泛化。

9.2 领域自适应的可学习性

无标签目标域样本能够帮助估计目标输入分布，却不直接提供目标标签。因此，领域自适应的论证需要完成两步：先说明源域风险与可观察的目标域输入为什么能够约束目标域风险，再控制有限样本和算法选择带来的估计误差。前一步由分歧、覆盖和标签机制等跨域条件承担，后一步则可以从整个假设空间或算法实际输出出发。只有两步同时成立，VC 维、

Rademacher 复杂度、算法稳定性或 PAC-Bayes 复杂度才能支持目标域保证。

9.2.1 跨域风险的连接与可识别条件

对二分类问题, 两个假设是否作出相同预测, 无须知道真实标签就能判断。例如, 两个邮件分类器在源域 10% 的输入上预测不同, 在目标域 40% 的输入上预测不同, 它们的分歧概率便改变了 0.3。这个变化提示我们: 两个假设在源域表现接近, 不足以说明它们在目标域也表现接近。

为了统一控制假设空间中的所有比较, 可以取全部假设对, 考察它们的分歧概率在两域间最大的变化。这就得到 $\mathcal{H} \triangle \mathcal{H}$ 散度 ($\mathcal{H} \triangle \mathcal{H}$ -divergence), 也称假设分歧散度; 系数 2 是该量的惯用约定。

定义 9.7 假设分歧散度 对非空二分类假设空间 $\mathcal{H} \subseteq \{0, 1\}^X$, 定义

$$d_{\mathcal{H} \triangle \mathcal{H}}(\mathcal{P}_S^X, \mathcal{P}_T^X) = 2 \sup_{h, g \in \mathcal{H}} |\mathbb{P}_{x \sim \mathcal{P}_S^X}(h(x) \neq g(x)) - \mathbb{P}_{x \sim \mathcal{P}_T^X}(h(x) \neq g(x))|. \quad (9.2)$$

也可以把来源本身作为待预测的域标签。对一个二分类器类 $\mathcal{G}$, 定义 $d_{\mathcal{G}} = 2 \sup_{g \in \mathcal{G}} |\mathbb{P}_S(g = 1) - \mathbb{P}_T(g = 1)|$ 。两域以相同概率出现、且 $\mathcal{G}$ 对取补封闭时, 最低域分类错误 $\varepsilon_{\text{dom}}^*$ 与该散度满足 $d_{\mathcal{G}} = 2(1 - 2\varepsilon_{\text{dom}}^*)$ 。容易区分两域, 表示这个分类器类能找到概率差较大的输入区域。但若域分类器仅取自 $\mathcal{H}$, 测得的是 $\mathcal{H}$ 散度; 要对应式 (9.2), 应使用 $\mathcal{G} = \mathcal{H} \triangle \mathcal{H}$ 。图 9.4 把这个区别与风险界中的三项放在一起。

还需要一个关于标签的条件: 假设空间中是否存在能够兼顾两域的假设。记 $\lambda = \inf_{g \in \mathcal{H}} (R_S(g) + R_T(g))$ 。当 λ 很小时, 至少可以找到两域期望风险之和很小的假设; 这里的 λ 由分布与假设空间共同决定, 与正则化系数无关。Ben-David 等的经典结论把源域期望风险、分歧散度与这个共同预测条件联系起来²。

定理 9.8 领域自适应的目标域期望风险界 设 R_S, R_T 均采用零一损失, $\mathcal{H}$ 为非空二分类假设空间。则对任意 $h \in \mathcal{H}$,

$$R_T(h) \leq R_S(h) + \frac{1}{2} d_{\mathcal{H} \triangle \mathcal{H}}(\mathcal{P}_S^X, \mathcal{P}_T^X) + \lambda. \quad (9.3)$$

证明. 取任意用于比较的假设 $g \in \mathcal{H}$ 。当 h 在目标域预测错误时, 要么 g 也预测错误, 要么 h 与 g 的预测不同。因此

$$R_T(h) \leq R_T(g) + \mathbb{P}_T(h(x) \neq g(x)).$$

² S. Ben-David, J. Blitzer, K. Crammer, A. Kulesza, F. Pereira, J. W. Vaughan, *A Theory of Learning from Different Domains* In Machine Learning, 2010, vol. 79, pp. 151–175

分歧散度控制同一分歧事件在两域的概率差，从而

$$\mathbb{P}_T(h \neq g) \leq \mathbb{P}_S(h \neq g) + \frac{1}{2}d_{\mathcal{H} \triangle \mathcal{H}}.$$

在源域中，两个二分类假设预测不同意味着至少一个预测错误，故 $\mathbb{P}_S(h \neq g) \leq R_S(h) + R_S(g)$ 。合并三步，再对 g 取下确界，得到结论。 ■




图 9.4 域分类器的错误只对应输入散度项。源输入均匀分布于 $[0, 1]^2$ ，目标支持沿 x_1 平移 δ ；圆点、方块的位置为教学构造，错误率由区域概率计算。 $\mathcal{H}$ 含双向阈值与常值假设，域分类器类取 $\mathcal{G} = \mathcal{H} \triangle \mathcal{H}$ 。其中 $g = h_0 \oplus h_\delta$ 在左侧浅色带预测源域， $h_a(x) = \mathbb{I}\{x_1 \geq a\}$ ；两域均等先验时，最小域错误为 $(1 - \delta)/2$ ， $d_g = 2\delta$ 。任务风险界还包含源风险及 $\lambda = \inf_{h \in \mathcal{H}} (R_S(h) + R_T(h))$ ，不能只由域错误决定。

分歧风险界允许标签规律以共同错误项 λ 进入结论，但无标签目标域样本不能直接估计这一项。若希望得到目标域超额期望风险可以趋于零的 PAC 保证，需要进一步规定源域标签为何仍能用于目标域。一种可以完整分析的设定是：两域共享条件标签分布，目标域出现的输入也能在源域观察到，而且两域输入频率的比例不会无限增大。

用 $w(x)$ 表示目标输入分布相对于源输入分布的密度比。更一般地， w 是满足 $\mathcal{P}_T^X(B) = \int_B w(x) d\mathcal{P}_S^X(x)$ 的非负函数，其中 B 为任意可测输入集合。若 $w(x) \leq \kappa$ 几乎处处成立，就有

$$\mathcal{P}_T^X(B) \leq \kappa \mathcal{P}_S^X(B).$$

这既排除了源域完全遗漏的目标区域，也限制了源域对重要目标区域的低估程度。例如，目标域一半邮件属于某种类型、源域只有百分之一属于该类型时，任何适用的 κ 都至少为 50。即使假设空间不变，这种稀少的源域观测也会增加学习难度。

在共享条件标签分布的前提下，目标域期望风险具有如下表达：

$$R_T(h) = \mathbb{E}_{(x,y) \sim \mathcal{P}_S} [w(x)\ell(h(x), y)]. \quad (9.4)$$

图 9.5 把密度比落实到源域样本的贡献上。目标域相对常见、源域相对稀少的输入获得较大权重；这些输入的标签仍然来自源域，其有效性依赖共享条件标签机制，而非只依赖两条输入密度曲线。




图 9.5 重要性权重重新分配源样本的贡献。在 $[0, 1]$ 上构造源密度 $p_S(x) = 1$ 、目标密度 $p_T(x) = 2x$ ，二者均积分为 1，因此 $w(x) = 2x$ 。五个源样本位置人为取为 0.1、0.3、0.5、0.7、0.9，权重依次为 0.2、0.6、1、1.4、1.8。圆点叠在目标密度上，面积与权重成正比，面积不表示局部样本数量。目标输入必须受到源输入覆盖；要使用风险恒等式，还需保持相同的条件标签分布。

等式来自把目标输入分布写为 $w(x)\mathcal{P}_S^X$ ，而保持同一条件标签分布。它的理论作用是把不可直接观察的目标域标签损失，表示成源域上可以估计的期望。下面暂时假定 w 已知，以明确给出一个可学习的分布族；未知密度比所需的附加条件将在有限样本分析中讨论。

9.2.2 基于假设空间的有限样本保证

前一小节建立了两种总体层面的风险连接：分歧距离给出带有共同错误项的上界，重要性加权则在共享条件标签分布和覆盖条件下给出风险恒等式。接下来固定这些跨域联系，考察怎样同时控制整个假设空间中的经验风险与期望风险偏差。VC 维适合控制二分类预测和分歧函数，Rademacher 复杂度与参数范数则可处理加权实值损失。

分歧距离与 VC 维 这个界尚未包含样本量，因为其中各项仍由真实分布定义。源域期望风险需要用带标签样本估计，分歧概率则可以用两域输入估计。两种估计都必须同时适用于全部假设或假设对，才能用于分析观察

样本后选出的模型。

记 $\hat{R}_S(h)$ 为源域经验风险, $\hat{d}$ 为把式 (9.2) 中的两个概率替换为各自样本频率得到的经验散度。另记

$$\mathcal{D}_{\mathcal{H}} = \{x \mapsto \mathbf{1}\{h(x) \neq g(x)\} : h, g \in \mathcal{H}\}.$$

它把“比较一对假设”转成一个取值为 0 或 1 的函数。若 $c_{\mathcal{H}}(n, \delta)$ 给出源域经验风险与期望风险之差的统一上界, $c_{\mathcal{D}}(n, \delta)$ 给出分歧频率与真实分歧概率之差的统一上界, 便有下列的有限样本结论。这里“统一”均指以概率至少 $1 - \delta$ 同时适用于相应函数空间的全部函数。

定理 9.9 有限样本的领域自适应期望风险界 在定理 9.8 的条件下, 以概率至少 $1 - \delta$, 对全部 $h \in \mathcal{H}$ 同时成立

$$\begin{aligned} R_T(h) \leq \hat{R}_S(h) + \frac{1}{2}\hat{d} + \lambda \\ + c_{\mathcal{H}}(n_S, \delta/3) + c_{\mathcal{D}}(n_S, \delta/3) + c_{\mathcal{D}}(n_T, \delta/3). \end{aligned} \quad (9.5)$$

证明. 分别对源域分类损失、源域分歧函数和目标域分歧函数应用一致收敛保证。三项保证中至少一项失败的概率不超过 $\delta/3 + \delta/3 + \delta/3 = \delta$, 这里不要求三项事件独立。在三项均成立时, 对每对 h, g , 两域真实分歧概率之差与经验分歧频率之差的偏差不超过两个 $c_{\mathcal{D}}$ 之和。取上确界后, 有

$$\frac{1}{2}d_{\mathcal{H} \triangle \mathcal{H}} \leq \frac{1}{2}\hat{d} + c_{\mathcal{D}}(n_S, \delta/3) + c_{\mathcal{D}}(n_T, \delta/3).$$

再用 $R_S(h) \leq \hat{R}_S(h) + c_{\mathcal{H}}(n_S, \delta/3)$ 代入总体期望风险界即可。■

VC 维在这里控制三项有限样本误差。若 $\text{VC}(\mathcal{H}) = d < \infty$, 分类损失的预测数目受 $\mathcal{H}$ 的生长函数控制。分歧函数由两个假设决定, 所以在 m 个输入上的不同预测数目至多为 $\Pi_{\mathcal{H}}(m)^2$ 。沿用式 (5.13) 的分析, 当 $1 \leq d \leq n$ 时, 两类 c 都可取为

$$O\left(\sqrt{\frac{d \log(2en/d) + \log(1/\delta)}{n}}\right).$$

因此, 为使每项抽样估计偏差不超过 ε , 充分的样本量具有 $O((d \log(1/\varepsilon) + \log(1/\delta))/\varepsilon^2)$ 的量级。无标签目标域样本在这个结论中用于估计分歧散度, 并不用于估计 λ 。

参数数量可以通过 VC 维进入这个样本量要求。例如, p 维输入上的仿射二分类假设空间具有 $p + 1$ 的 VC 维。对含 p 个参数、深度为 L 且满足第 8 章条件的 ReLU 网络, 可使用 $d = O(pL \log p)$ 的 VC 维上界, 再代入上面的样本量公式。参数少通常有助于控制这部分抽样估计偏差, 却不会

自动减小 λ 。即使所有有限样本误差都趋于零，分布差异和共同预测条件仍然存在。因而式 (9.5) 给出了目标域期望风险的上界，还不是整个分布族上的 PAC 可学习性刻画。

覆盖条件下的加权经验风险 式 (9.4) 把目标域风险写成源域上的加权期望。若密度比已知且一致有界，便可以对整个有限假设空间同时估计这一加权风险，并由经验风险最小化得到目标域超额期望风险保证。

定理 9.10 已知密度比下的迁移样本量界 设 $|\mathcal{H}| = N < \infty$, $\ell \in [0, 1]$, 两域共享条件标签分布, 且已知密度比 $0 \leq w \leq \kappa$ 。给定 n 个独立源域样本, 令

$$\hat{R}_w(h) = \frac{1}{n} \sum_{i=1}^n w(x_i) \ell(h(x_i), y_i), \quad \hat{h} \in \arg \min_{h \in \mathcal{H}} \hat{R}_w(h).$$

则以概率至少 $1 - \delta$,

$$R_T(\hat{h}) - R_{T, \mathcal{H}}^* \leq \kappa \sqrt{\frac{2 \log(2N/\delta)}{n}}. \quad (9.6)$$

特别地, 若 $n \geq 2\kappa^2 \log(2N/\delta)/\varepsilon^2$, 则目标域超额期望风险以概率至少 $1 - \delta$ 不超过 ε 。

证明. 对每个固定假设, $w(x_i) \ell(h(x_i), y_i)$ 取值在 $[0, \kappa]$, 其期望由式 (9.4) 给出。Hoeffding 不等式与有限假设空间的概率求和保证, 以概率至少 $1 - \delta$, 全部假设同时满足

$$|R_T(h) - \hat{R}_w(h)| \leq a_n, \quad a_n = \kappa \sqrt{\frac{\log(2N/\delta)}{2n}}.$$

取目标域期望风险最小的 $h^* \in \mathcal{H}$, 由经验最优性有

$$R_T(\hat{h}) \leq \hat{R}_w(\hat{h}) + a_n \leq \hat{R}_w(h^*) + a_n \leq R_T(h^*) + 2a_n.$$

代入 a_n 得到结论。 ■

这个定理回答了一个具体的可学习性问题：在共享标签机制、统一覆盖常数 κ 且密度比已知的分布族上，有限假设空间可以达到任意精度的目标域超额期望风险。证明用一个经验最小化规则说明这样的学习算法存在；核心依据是目标域期望风险能够被源域数据一致估计。给出的 κ^2 样本量依赖是充分条件，并不声称是最优依赖。

若密度比未知，仅有有限 VC 维还不够。需要额外说明能否从无标签两域样本估计 w ，以及估计误差如何下降。比如，在独立于上述带标签训练

样本的数据上构造 $0 \leq \hat{w} \leq \kappa$, 记

$$b_w = \mathbb{E}_{x \sim \mathcal{P}_S^X} |\hat{w}(x) - w(x)|.$$

由于损失不超过 1, 对所有 h 都有 $|\mathbb{E}_S[\hat{w}\ell(h(x), y)] - R_T(h)| \leq b_w$ 。在保证该密度比误差的事件上重复证明, 目标域超额期望风险上界增加 $2b_w$, 再合并该事件的失败概率。只有 b_w 也能在允许的分布族上一致趋于零, 这一路径才继续给出 PAC 保证。密度比的可估计性是对分布族的要求, 不能由预测假设空间的复杂度代替。

共享标签机制同样不能省去。若条件标签分布有所改变, 令

$$b_{\text{cond}} = \mathbb{E}_{x \sim \mathcal{P}_T^X} \text{TV}(\mathcal{P}_S(\cdot | x), \mathcal{P}_T(\cdot | x)),$$

其中总变差距离 TV 是两个概率分布对同一事件赋予概率的最大差。对 $[0, 1]$ 值损失, 式 (9.4) 两端的差至多为 b_{cond} , 上述超额期望风险界因此再增加 $2b_{\text{cond}}$ 。一个固定为正的残余项只能支持近似保证, 不能保证任意小的目标域超额期望风险。

标签偏移需要另一种可识别条件。若源域两个类别的条件输入分布完全相同, 那么无论目标域两个类别的比例怎样改变, 无标签目标输入分布都相同, 算法不能据此恢复类别比例。对于有限标签, 类条件输入分布的线性独立性可以使混合比例具有唯一性; 有限样本保证还需控制恢复比例时的误差放大程度。这说明不同偏移设定需要不同的跨域条件, 不能共享一个仅由参数数量决定的可学习性判据。

参数范数与加权 Rademacher 复杂度 VC 维适合描述整个二分类假设空间的最坏情形。对高维线性模型或神经网络, 这种上界可能很大, 而学到的参数只处于一个较小的范数范围。第 8 章已经说明参数大小可以通过 Rademacher 复杂度控制期望风险; 在迁移问题中, 还需要追踪分布偏移怎样放大这一复杂度。

沿用前文的已知密度比设定。考虑 $\mathbb{R}^p$ 上的线性预测 $f_\theta(\mathbf{x}) = \langle \theta, \mathbf{x} \rangle$, 其中 $\|\theta\|_2 \leq B$, $\|\mathbf{x}\|_2 \leq r$ 。损失 $\ell(t, y)$ 对预测值 t 是 L -Lipschitz 的, 即预测值相差 a 时, 损失相差至多 $L|a|$, 并且损失取值在 $[0, 1]$ 中。范数限制约束模型输出对输入的敏感程度; 密度比则决定每个源域输入对目标域期望风险的贡献。

定理 9.11 范数受限线性预测的迁移保证 在上述条件下, 令 $\hat{\theta}$ 最

小化 n 个源域样本上的 $\hat{R}_w$ 。以概率至少 $1 - \delta$,

$$R_T(f_{\hat{\theta}}) - \inf_{\|\theta\|_2 \leq B} R_T(f_{\theta}) \leq \frac{4\kappa LBr}{\sqrt{n}} + 6\kappa \sqrt{\frac{\log(4/\delta)}{2n}}. \quad (9.7)$$

因此, 存在普适常数 C , 当 $n \geq C\kappa^2((LBr)^2 + \log(4/\delta))/\varepsilon^2$ 时, 目标域超额期望风险以概率至少 $1 - \delta$ 不超过 ε 。

证明. 记 $\mathcal{F}_w$ 为加权损失函数空间。固定源域样本后, 令 $w_i = w(x_i)$, σ_i 为相互独立的随机正负号。由 Lipschitz 收缩性质与欧氏范数的对偶关系,

$$\begin{aligned} \hat{\mathcal{R}}_S(\mathcal{F}_w) &\leq \frac{LB}{n} \mathbb{E}_{\sigma} \left\| \sum_{i=1}^n \sigma_i w_i \mathbf{x}_i \right\|_2 \\ &\leq \frac{LB}{n} \sqrt{\sum_{i=1}^n w_i^2 \|\mathbf{x}_i\|_2^2} \leq \frac{\kappa LBr}{\sqrt{n}}. \end{aligned}$$

第二步使用 Cauchy-Schwarz 不等式; 展开范数平方后, 不同随机正负号的交叉项期望为零。收缩时可先减去每个样本上的 $w_i \ell(0, y_i)$, 这些与参数无关的项不改变 Rademacher 复杂度。

对加权损失 $f \in \mathcal{F}_w$ 及其补函数 $\kappa - f$, 分别应用基于经验 Rademacher 复杂度的期望风险界。两者都取值于 $[0, \kappa]$; 各分配 $\delta/2$ 的失败概率, 便能同时控制期望风险高于和低于经验风险的偏差, 得到

$$\sup_{\|\theta\|_2 \leq B} |R_T(f_{\theta}) - \hat{R}_w(f_{\theta})| \leq \frac{2\kappa LBr}{\sqrt{n}} + 3\kappa \sqrt{\frac{\log(4/\delta)}{2n}}.$$

经验最小化的目标域超额期望风险不超过这个统一偏差的两倍, 证明完成。■

与参数计数相比, 这个结论直接使用 B, r, L , 没有显式出现参数维数 p 。但“没有出现 p ”须在这些量不随 p 增大的前提下理解。例如, 每个输入坐标都具有固定尺度时, 输入范数 r 可能随 $\sqrt{p}$ 增长, 维度仍会间接进入样本量。增大覆盖常数 κ 也会增大所需源域样本量, 这反映了稀少源域区域对目标域预测的重要性。

零一损失并不满足这里的 Lipschitz 条件。要用于分类, 可以选择第 8 章介绍的间隔损失, 以 $L = 1/\gamma$ 引入间隔 γ , 再用目标域间隔损失上界控制目标域分类期望风险。此时得到的是带有间隔条件的分类保证, 不能直接改称相对于所有零一损失分类器的不可知 PAC 结论。对深度网络, 也可用各层谱范数等量控制相应损失函数空间的 Rademacher 复杂度, 再代入同样的跨域风险分析。一般损失下的分布差异与 Rademacher 分析可参见 Mansour 等的工作³。

³ Y. Mansour, M. Mohri, A. Ros-tamizadeh, *Domain Adaptation: Learning Bounds and Algorithms* In Proceedings of the 22nd Annual Conference on Learning Theory, 2009

9.2.3 基于输出的有限样本保证

前一小节同时控制假设空间中的全部候选, 所得结论适用于观察样本后选出的任意成员。本节改为分析算法实际输出: 稳定性控制输出对训练样本的敏感程度, PAC-Bayes 则评价训练结果附近的随机预测器。两条路线都只控制有限样本带来的误差, 仍须保留相应的跨域条件和经验表现。

算法稳定性与可学习性 参数范数限制整个可选假设空间, 算法稳定性则描述训练数据变化时, 算法实际输出的假设会改变多少。二者回答不同问题: 参数较小不保证替换一个样本后参数变化较小; 反过来, 一个稳定算法也可能始终输出预测不准的固定假设。要从稳定性推出学习, 还需要控制算法对经验目标的优化误差。

在已知密度比的协变量偏移设定下, 这一关系可以直接由第7章得到。假设替换一个源域样本后, 算法输出在任意输入标签对上的损失期望至多变化 β_n , 即算法对原损失具有均匀稳定性。乘上 $w(x) \leq \kappa$ 后, 加权损失的均匀稳定性参数至多为 $\kappa\beta_n$ 。这里均匀稳定性的期望只针对算法内部随机性。

定理 9.12 稳定性条件下的迁移可学习性 设 $\ell \in [0, 1]$, 两域共享条件标签分布, 且已知密度比 $0 \leq w \leq \kappa$ 。算法 A 输出 $\mathcal{H}$ 中的假设, 对原损失具有均匀稳定性 β_n , 并满足

$$\mathbb{E} \left[\hat{R}_w(A(S)) - \inf_{h \in \mathcal{H}} \hat{R}_w(h) \right] \leq \rho_n.$$

则

$$\mathbb{E}[R_T(A(S)) - R_{T, \mathcal{H}}^*] \leq \kappa\beta_n + \rho_n. \quad (9.8)$$

若 $\kappa\beta_n + \rho_n$ 在允许的分布族上一致趋于零, 则该设定 PAC 可学习。具体地, 使 $\kappa\beta_n + \rho_n \leq \varepsilon\delta$, 便足以保证目标域超额期望风险以概率至少 $1 - \delta$ 不超过 ε 。

证明. 加权损失的均匀稳定性与式 (9.4) 给出

$$\mathbb{E}[R_T(A(S)) - \hat{R}_w(A(S))] \leq \kappa\beta_n.$$

对任意固定 $h \in \mathcal{H}$, 又有

$$\mathbb{E} \inf_{g \in \mathcal{H}} \hat{R}_w(g) \leq \mathbb{E} \hat{R}_w(h) = R_T(h).$$

将目标域超额期望风险分解为期望风险与经验风险之差、经验优化误差以及最优经验风险与最优目标域期望风险之差, 合并上述不等式并对 h 取下

确界, 得到期望结论。由于 $A(S) \in \mathcal{H}$, 目标域超额期望风险非负, 对它使用 Markov 不等式即可得到所述概率保证。 ■

这里明确保留了两项条件。 $\kappa\beta_n$ 控制目标域期望风险与加权经验风险之间的期望泛化差, ρ_n 控制算法输出距离加权经验最优值还有多远。若 $\beta_n \leq c/n$ 、 $\rho_n \leq a/n$, 上述充分条件为 $n \geq (\kappa c + a)/(\varepsilon\delta)$ 。这个由期望经 Markov 不等式得到的样本量并不追求最优置信度依赖, 却直接说明稳定性怎样支持迁移可学习性。

参数稳定性也由同一入口发挥作用。若损失关于参数是 G -Lipschitz 的, 替换一个源域样本使输出参数的期望距离至多为 s_n , 则 $\beta_n \leq Gs_n$, 式(9.8)的右侧变为 $\kappa Gs_n + \rho_n$ 。正则化或随机梯度下降的参数稳定性结论因而可以用于迁移分析, 但必须核对其应用的是当前加权经验目标, 以及相应的光滑性、凸性等条件。脱离共享标签机制与覆盖条件, 即使参数完全不变, 也不能保证目标域标签被正确预测。

参数分布与 PAC-Bayes 对随机训练或随机预测的模型, 还可以通过参数分布描述复杂度。第 8 章的 PAC-Bayes 理论用后验分布偏离先验分布的程度控制源域期望风险与经验风险之差。迁移到目标域时, 这个复杂度项仍然有效, 但还需分析两个域上的预测分歧和共同错误怎样变化。

考虑二分类与零一损失。令 Q 为假设上的后验分布, Gibbs 预测每次从 Q 抽取一个假设进行预测, 其域 D 上的期望风险为 $r_D(Q) = \mathbb{E}_{h \sim Q} R_D(h)$ 。独立抽取 $h, g \sim Q$ 后, 记 $d_D(Q)$ 为二者在域 D 上的分歧概率, $e_D(Q)$ 为二者同时预测错误的概率, 即

$$\begin{aligned} d_D(Q) &= \mathbb{E}_{h, g \sim Q} \mathbb{P}_{x \sim \mathcal{P}_D}(h(x) \neq g(x)), \\ e_D(Q) &= \mathbb{E}_{h, g \sim Q} \mathbb{P}_{(x, y) \sim \mathcal{P}_D}(h(x) \neq y, g(x) \neq y). \end{aligned}$$

分歧可以用无标签输入观察, 共同错误仍需要标签。这个区分使参数分布理论保留了迁移问题的信息边界, 而不是把全部困难归入参数复杂度。

定理 9.13 参数分布的跨域期望风险界 设 P_0 为独立于 n 个源域训练样本的先验分布。以概率至少 $1 - \delta$, 对所有 $Q \ll P_0$ 同时有

$$\begin{aligned} r_T(Q) &\leq \hat{r}_S(Q) + \sqrt{\frac{D_{\text{KL}}(Q \| P_0) + \log((n+1)/\delta)}{2n}} \\ &\quad + \frac{1}{2} |d_T(Q) - d_S(Q)| + |e_T(Q) - e_S(Q)|, \end{aligned} \quad (9.9)$$

其中 $\hat{r}_S(Q) = \mathbb{E}_{h \sim Q} \hat{R}_S(h)$ 。

证明. 固定 (x, y) , 令 $p = \mathbb{P}_{h \sim Q}(h(x) \neq y)$ 。两个独立抽取的二分类假设分

歧的概率为 $2p(1-p)$ ，同时错误的概率为 p^2 。等式 $p = \frac{1}{2} \cdot 2p(1-p) + p^2$ 在域 D 上取期望后给出

$$r_D(Q) = \frac{1}{2}d_D(Q) + e_D(Q).$$

分别代入 $D = T, S$ 并相减，可得

$$r_T(Q) \leq r_S(Q) + \frac{1}{2}|d_T(Q) - d_S(Q)| + |e_T(Q) - e_S(Q)|.$$

对 $r_S(Q)$ 应用定理 8.19 的 PAC-Bayes 上界，得到结论。 ■

这个推导采用 Germain 等研究中的分歧与共同错误分解⁴。公式中的平方根项控制源域有限样本误差，另外两项控制同一后验预测分布在两域间的变化。增加源域样本只能直接减小前一项；目标域共同错误差若没有结构条件控制，目标域无标签样本仍不足以使整个上界趋于所需精度。

⁴ P. Germain, A. Habrard, F. Laviolette, E. Morvant, *An Improvement to the Domain Adaptation Bound in a PAC-Bayesian Context* In arXiv preprint arXiv:1501.03002, 2015

参数大小与参数分布在这里可以联系起来。例如，参数先验与后验分别为具有相同协方差 $\sigma^2 I$ 的高斯分布，均值为 μ_0 和 μ ，则

$$D_{KL}(Q||P_0) = \frac{\|\mu - \mu_0\|_2^2}{2\sigma^2}.$$

较小的参数位移可以降低这一复杂度项；增大 σ 虽也减小该表达式，却会改变随机预测并可能提高经验风险。源域经验风险与跨域残余项均已足够小时，给定一个与样本无关的上界 $D_{KL}(Q||P_0) \leq K$ 后， $n \geq [K + \log((n+1)/\delta)]/(2\varepsilon^2)$ 便足以使复杂度项不超过 ε 。这是该期望风险上界给出的充分样本量条件，不是所有学习算法都必须满足的下界。若 Q 由数据选择，这个式子是对所选后验的风险证书；要得到预先给定的样本量，还需给出 KL 项的统一上界。

若把预训练模型用于构造先验，也必须保证该先验独立于这里用于计算经验风险的源域样本，或另行采用允许数据依赖先验的理论。

这一结论评价 Gibbs 预测的目标域期望风险，并不直接评价后验均值参数对应的确定性模型。与稳定性路线相比，PAC-Bayes 控制参数分布相对于先验的复杂度，稳定性控制训练样本变化引起的输出变化。两者都可以刻画深度模型的泛化能力，但在迁移问题中都需要额外的跨域联系；没有任何一个参数复杂度量能够单独补出未观察到的目标标签。

9.2.4 理论比较与适用边界

领域自适应的各条路线都要区分跨域信息条件与有限样本控制。分歧距离路线用源域风险、输入分歧和共同错误项连接目标域风险；重要性加权路线依赖共享条件标签分布、输入覆盖和密度比；参数分布路线则对 Gibbs

预测器分解两域的分歧与共同错误。它们规定了不同的总体风险桥梁，不能仅因都出现复杂度项就视为同一种假设。

在风险桥梁固定以后，VC 维、Rademacher 复杂度和参数范数控制整个候选空间的估计偏差，算法稳定性控制实际训练输出对样本变化的反应，PAC-Bayes 相对熵控制随机预测器相对于先验的复杂度。空间复杂度小不推出算法稳定，稳定算法也可能因为经验表现很差而无法学习；PAC-Bayes 给出的 Gibbs 风险还不能直接改写成后验均值参数的风险。

更重要的是，有限样本项趋于零不等于迁移问题已经可学习。若 λ 、密度比估计误差、条件标签变化或共同错误差保持为正，已有观测仍不足以把目标域超额期望风险压到任意精度。领域自适应的 PAC 结论必须同时说明允许的分布族、可观察信息、跨域残余项和所采用的复杂度或稳定性条件。

9.3 领域泛化的可学习性

领域自适应可以利用目标域输入估计分布变化，领域泛化连这部分数据也没有。若目标环境可以任意选择，定理 9.3 的反例仍然适用。因此，领域泛化理论必须明确新环境与训练环境的联系，以及“泛化成功”针对哪一种评价目标。

一种设定要求每个允许的目标域都保留共同预测机制，并限制它相对于训练域的覆盖关系。这能够导出对每个目标域的期望风险保证。另一种设定把环境本身看作随机对象，训练环境与未来环境来自同一环境分布；此时控制的是新环境上的平均期望风险。下面分别建立两类保证，再比较它们的评价对象、概率来源和适用边界。

9.3.1 逐目标域保证

多个训练域可以覆盖彼此遗漏的输入。设有 K 个源域分布 $\mathcal{P}_1, \dots, \mathcal{P}_K$ ，用 $\bar{\mathcal{P}} = K^{-1} \sum_{e=1}^K \mathcal{P}_e$ 表示它们的均匀混合分布。等概率选择一个训练域，再从该域抽取一个观测，就得到 $\bar{\mathcal{P}}$ 的一个样本。若目标域的重要输入都在这个混合分布中有足够的出现机会，便有可能由训练域学习目标域需要的预测规律。

输入覆盖仍须与标签机制结合。对二分类问题，假定各训练域和允许的目标域共享 $\eta(x) = \mathbb{P}(y = 1 | x)$ ，并且贝叶斯分类器 $h^*(x) = \mathbf{1}\{\eta(x) \geq 1/2\}$ 属于 $\mathcal{H}$ 。这比“所有训练域上存在同一个经验最优假设”强：它直接规定同一输入的条件标签规律在未来环境中仍然成立。

在这一条件下，可以比较同一假设相对于 h^* 多犯的错误。若 $h(x) = h^*(x)$ ，条件超额错误概率为零；若两者不同，条件超额错误概率为 $|2\eta(x) -$

1]。因而对任一共享该机制的域 D ,

$$R_D(h) - R_D(h^*) = \mathbb{E}_{x \sim \mathcal{P}_D^X} [2\eta(x) - 1 | \mathbf{1}\{h(x) \neq h^*(x)\}]. \quad (9.10)$$

被平均的函数非负且在各域相同, 输入覆盖条件就能够把训练域的超额期望风险转换为目标域的超额期望风险。

定理 9.14 共享标签机制下的领域泛化 设 $\mathcal{H}$ 为含 $N < \infty$ 个假设的二分类假设空间, 采用零一损失。训练域与全部允许的目标域共享 η , 相应贝叶斯分类器 h^* 属于 $\mathcal{H}$ 。若对每个允许的目标域与每个可测输入集合 B 都有

$$\mathcal{P}_T^X(B) \leq \kappa \overline{\mathcal{P}}^X(B),$$

则从 $\overline{\mathcal{P}}$ 独立抽取 m 个带标签样本并进行 ERM, 以概率至少 $1 - \delta$, 对全部允许的目标域同时有

$$R_T(\hat{h}) - R_{T,\mathcal{H}}^* \leq \kappa \sqrt{\frac{2 \log(2N/\delta)}{m}}. \quad (9.11)$$

故 $m \geq 2\kappa^2 \log(2N/\delta)/\varepsilon^2$ 是保证目标域超额期望风险不超过 ε 的充分样本量条件。

若进一步有 $\eta(x) \in \{0, 1\}$ 几乎处处成立, 则任意与样本一致的假设都满足可实现 PAC 保证, 只需

$$m \geq \frac{\kappa}{\varepsilon} (\log N + \log(1/\delta)).$$

证明. 由式 (9.10) 与覆盖条件, 对任意 $h \in \mathcal{H}$,

$$R_T(h) - R_T(h^*) \leq \kappa (R_{\overline{\mathcal{P}}}(h) - R_{\overline{\mathcal{P}}}(h^*)).$$

h^* 在混合分布及各目标域中都是 $\mathcal{H}$ 内最优假设。有限假设空间的不可知 PAC 样本量界给出

$$R_{\overline{\mathcal{P}}}(\hat{h}) - R_{\overline{\mathcal{P}}}(h^*) \leq \sqrt{\frac{2 \log(2N/\delta)}{m}}.$$

控制混合分布超额期望风险的同一个事件适用于全部目标域, 因此得到同时保证。

在可实现情形, $R_D(h^*) = 0$ 。若某个假设在某个允许目标域上的期望风险大于 ε , 则它在混合分布上的期望风险必大于 ε/κ 。这样的固定假设与 m 个样本一致的概率至多为 $\exp(-m\varepsilon/\kappa)$ 。对至多 N 个假设的失败概率求和, 再令结果不超过 δ , 得到第二个样本量条件。 ■

这个结论满足定义 9.5 的逐目标域领域泛化要求，而且使用同一个高概率事件同时控制全部允许目标域，因而比定义中的逐目标域事件更强。算法不需要知道目标域的密度比，也不观察目标域样本，只需学习共享的最优分类器；覆盖条件保证它在源域混合分布上的错误不会在目标域被任意放大。这里的抽样模型是每次独立选择训练域并抽样，固定每域样本量的分层抽样应另行处理，不能直接把它宣称为混合分布的独立同分布样本。

有限性也可由更一般的复杂度控制替代。若 $\mathcal{H}$ 在混合分布上满足偏差不超过 $c_{\mathcal{H}}(\mathbf{m}, \delta)$ 的一致收敛保证，同一证明给出目标域超额期望风险至多为 $2\kappa c_{\mathcal{H}}(\mathbf{m}, \delta)$ 。有限 VC 维由此提供领域泛化的一个充分条件；有界范数与合适损失下的 Rademacher 复杂度也可用于建立对应的源域估计保证。要把一般损失的源域超额期望风险转换到目标域，还须验证类似式 (9.10) 的非负条件超额损失关系。

这些条件也解释了不变性理论的作用。若已知表示 $\Phi(x)$ 保留共同标签机制，可以在表示空间中要求共享条件标签分布与覆盖，再对 $h \circ \Phi$ 进行上述分析。若表示由数据学习，就还需要证明训练环境能够识别这样的表示，并控制整个表示与预测器组合空间的复杂度。仅仅在有限训练环境中找到同一最优预测头，不能证明它在全部未来环境中仍然最优。不变风险最小化提出了寻找跨环境共同最优预测关系的思路⁵。

在本章的理论问题中，关键是这种不变关系何时能够由训练环境确定。若训练环境变化不足，某个偶然相关的特征也可能在所有训练域上看起来稳定，却在目标域失效。IRM 的风险分析揭示了这类限制⁶。因此，不变性必须落实为关于允许环境、表示可识别性与假设空间的条件，不能仅用一个训练约束替代未来环境的假设。

表示充分性与近似误差 逐目标域保证还需要区分有限样本造成的估计误差与表示本身造成的近似误差。固定一个已学习表示 Φ ，记 $\mathcal{H}_{\Phi} = \{g \circ \Phi : g \in \mathcal{G}\}$ 。相对于目标域贝叶斯风险 R_T^{Bayes} ，可分解为

$$R_T(\hat{h}) - R_T^{\text{Bayes}} = \left[R_T(\hat{h}) - \inf_{h \in \mathcal{H}_{\Phi}} R_T(h) \right] + \left[\inf_{h \in \mathcal{H}_{\Phi}} R_T(h) - R_T^{\text{Bayes}} \right]. \quad (9.12)$$

若只训练一个参数很少的预测头，可能更容易控制第一项，却无法保证第二项较小。例如，表示若把目标类别不同的输入映射到同一点，任何预测头都无法再区分它们。若表示与预测头在同一批数据上共同选择，也不能把表示事后当作独立固定对象而只计算预测头复杂度。共享机制、覆盖和复杂度控制只有与表示充分性结合，才能共同支持逐目标域保证。

⁵ M. Arjovsky, L. Bottou, I. Gulrajani, D. Lopez-Paz, *Invariant Risk Minimization* In arXiv preprint arXiv:1907.02893, 2019

⁶ E. Rosenfeld, P. Ravikumar, A. Risteski, *The Risks of Invariant Risk Minimization* In International Conference on Learning Representations, 2021

9.3.2 环境平均保证

对每个允许目标域都保留共同标签机制，是较强的要求。定义 9.6 采用另一条路径：不指定每个目标域，而是假定环境来自同一个总体。例如，把不同用户视为不同环境，训练用户和未来用户都从同一个用户总体独立抽取。理论评价的对象便是未来随机用户上的平均期望风险。

令 $\mathcal{Q}$ 为环境分布；从 $\mathcal{Q}$ 抽取一次，得到一个输入标签联合分布 $\mathcal{P}$ 。训练时独立抽取 K 个环境 $\mathcal{P}_1, \dots, \mathcal{P}_K$ ，再在每个环境内独立抽取 n 个样本 $z_{e,i} = (x_{e,i}, y_{e,i})$ 。给定各环境后，所有样本相互独立。对一个不随目标域重新训练的假设 h ，定义

$$R_{\mathcal{Q}}(h) = \mathbb{E}_{\mathcal{P} \sim \mathcal{Q}} R_{\mathcal{P}}(h), \quad \hat{R}_S(h) = \frac{1}{Kn} \sum_{e=1}^K \sum_{i=1}^n \ell(h, z_{e,i}). \quad (9.13)$$

$\ell(h, z)$ 是 $\ell(h(x), y)$ 的简写。 $R_{\mathcal{Q}}$ 先在每个环境内平均损失，再对环境取平均； $\hat{R}_S$ 是从两层抽样得到的经验估计。

这一区别带来两类样本量。增加每个环境内的样本数 n ，能够更准确地评价已见环境；增加环境数 K ，才能更充分地了解环境之间的差异。固定 K 后无限增加 n ，并不等于观察了更多独立环境。

图 9.6 比较了总观测数相同的两种扩充方式。在原有环境中继续采样，会增加每行中的观测；另抽独立环境，则会增加行数。环境平均风险还要对环境分布 $\mathcal{Q}$ 取平均，所以这两种增加样本的方式不能互相替代。

定理 9.15 随机环境中的一致收敛与可学习性 设 $|\mathcal{H}| = N < \infty$ 、 $\ell \in [0, 1]$ ，数据按上述两层模型抽取。以概率至少 $1 - \delta$ ，对所有 $h \in \mathcal{H}$ 同时有

$$|R_{\mathcal{Q}}(h) - \hat{R}_S(h)| \leq \sqrt{\frac{\log(4N/\delta)}{2K}} + \sqrt{\frac{\log(4N/\delta)}{2Kn}}. \quad (9.14)$$

令 $\hat{h}$ 最小化 $\hat{R}_S$ ，则其环境平均超额期望风险 $R_{\mathcal{Q}}(\hat{h}) - \inf_{h \in \mathcal{H}} R_{\mathcal{Q}}(h)$ 不超过上述右侧的两倍。特别地，令两项各不超过 $\varepsilon/4$ ，即可得到定义 9.6 中精度 ε 、置信度 $1 - \delta$ 的 PAC 保证。

证明. 在真实环境平均期望风险和经验风险之间插入已见环境的期望风险平均值：

$$\begin{aligned} |R_{\mathcal{Q}}(h) - \hat{R}_S(h)| &\leq \left| R_{\mathcal{Q}}(h) - \frac{1}{K} \sum_{e=1}^K R_{\mathcal{P}_e}(h) \right| \\ &\quad + \left| \frac{1}{K} \sum_{e=1}^K R_{\mathcal{P}_e}(h) - \hat{R}_S(h) \right|. \end{aligned}$$




图 9.6 环境数量 K 与环境内样本数 n 对应不同的抽样层。每行边界代表一个环境，圆点代表其中的观测。左侧从同一环境分布 $\mathcal{Q}$ 独立抽取 3 个环境，各取 3 个观测；中间的空心点表示在原有 3 个环境中继续抽取的观测，每个环境增至 6 个；右侧从 $\mathcal{Q}$ 新抽取 3 个独立环境，每个环境仍取 3 个观测。中、右都有 18 个观测，只有右侧增加了独立环境数量。图中数量为教学构造，不对应实测数据。

第一项包含 K 个独立环境，每个 $R_{\mathcal{P}_e}(h)$ 都在 $[0, 1]$ 中。对固定 h 应用 Hoeffding 不等式，再对 N 个假设求和，以失败概率 $\delta/2$ 得到第一项的统一上界。

第二项在给定全部 $\mathcal{P}_e$ 后，是 Kn 个独立、有界但未必同分布的观测相对于各自期望的平均偏差。Hoeffding 不等式仍然适用，再对 N 个假设求和，以条件失败概率 $\delta/2$ 得到第二项上界。该保证对每组环境都成立，因此无条件失败概率也不超过 $\delta/2$ 。合并两个事件得到一致收敛结论，ERM 的超额期望风险再由两次偏差控制得到。 ■

由这个充分条件可取

$$K \geq \frac{8 \log(4N/\delta)}{\varepsilon^2}, \quad Kn \geq \frac{8 \log(4N/\delta)}{\varepsilon^2}.$$

由于 $n \geq 1$ ，前者已经蕴含后者；这反映了当前对任意环境分布的最坏情形分析中，独立环境数量可能成为主要限制。并不是环境内的数据没有作用，而是没有进一步限制环境差异时，仅增加同一环境内的观测无法排除未见环境的变化。

对于无限假设空间，可以把证明中的两次有限计数替换成两层复杂度分析：环境层需要控制函数 $\mathcal{P} \mapsto R_{\mathcal{P}}(h)$ 的复杂度，环境内需要控制损失函数 $z \mapsto \ell(h, z)$ 的复杂度。参数数量、范数或 Rademacher 复杂度必须用于

它们实际约束的那一层。若学习的是共享表示与各任务预测头，还需分别记录表示复杂度、预测头复杂度和任务数量；多任务表示学习与学习新任务的理论正是从这种区分中获得样本量结论⁷。

这里的 PAC 比较对象是一个共同假设在随机新环境上的平均表现。它不保证每个环境的期望风险都小，也不与“知道目标环境后为它单独选择的最优假设”比较。若要学习一个能够根据目标域数据适应的算法，输出对象和比较基准都需要重新定义，不能沿用本定理而不作说明。

⁷ A. Maurer, M. Pontil, B. Romera-Paredes, *The Benefit of Multitask Representation Learning* In Journal of Machine Learning Research, 2016, vol. 17, no. 81, pp. 1–32

基于环境稳定性的算法保证 前文的一致收敛证明同时控制整个假设空间。若希望分析实际算法，可以把第7章的稳定性理论用于环境层：将一个训练环境的全部样本换成另一个环境的样本，考察算法输出的预测损失变化。

记 $D_e = (z_{e,1}, \dots, z_{e,n})$ 为第 e 个环境提供的数据块， $\mathcal{S} = (D_1, \dots, D_K)$ 为全部训练数据。虽然同一块内的观测在不条件化环境时通常相关，不同的 D_e 仍然相互独立且同分布。对一个新块 D ，定义块损失 $L(h, D) = n^{-1} \sum_{i=1}^n \ell(h, z_i)$ 。它的总体期望正好是 $R_Q(h)$ ，因此可以把每个环境块当作稳定性分析的一个观测单位。

定义 9.16 环境均匀稳定性 设 A 接收 K 个环境数据块。若对任意仅在一个数据块上不同的 $\mathcal{S}, \mathcal{S}'$ ，以及任意测试观测 z ，均有

$$|\mathbb{E}_A \ell(A(\mathcal{S}), z) - \mathbb{E}_A \ell(A(\mathcal{S}'), z)| \leq \gamma_K,$$

则称 A 具有参数为 γ_K 的环境均匀稳定性。

定理 9.17 环境稳定性与平均可学习性 在定理 9.15 的抽样模型下，允许 $\mathcal{H}$ 无限。若 A 输出 $\mathcal{H}$ 中的假设，具有环境均匀稳定性 γ_K ，且

$$\mathbb{E} \left[\hat{R}_{\mathcal{S}}(A(\mathcal{S})) - \inf_{h \in \mathcal{H}} \hat{R}_{\mathcal{S}}(h) \right] \leq \rho_{K,n},$$

则

$$\mathbb{E} \left[R_Q(A(\mathcal{S})) - \inf_{h \in \mathcal{H}} R_Q(h) \right] \leq \gamma_K + \rho_{K,n}.$$

若右侧在允许的环境分布族上一致趋于零，则满足定义 9.6 中的环境平均 PAC 要求；令右侧不超过 $\varepsilon \delta$ 便得到相应的充分样本量条件。

证明. 环境均匀稳定性也控制块损失 L 的变化，因为对块内每个观测的损失变化取平均仍不超过 γ_K 。不同数据块独立同分布，故均匀稳定性定理给出

$$\mathbb{E}[R_Q(A(\mathcal{S})) - \hat{R}_{\mathcal{S}}(A(\mathcal{S}))] \leq \gamma_K.$$

对任意固定 h , $\mathbb{E}\hat{R}_S(h) = R_Q(h)$, 从而 $\mathbb{E}\inf_h \hat{R}_S(h) \leq \inf_h R_Q(h)$ 。加入经验优化误差即得期望结论, 再对非负的超额期望风险应用 Markov 不等式。 ■

普通样本稳定性与环境稳定性之间也有明确联系。如果替换任意单个观测的均匀稳定性参数为 β_{Kn} , 逐个替换一个块内的 n 个观测并累加损失变化, 就得到 $\gamma_K \leq n\beta_{Kn}$ 。例如, $\beta_{Kn} = O(1/(Kn))$ 只能直接推出 $\gamma_K = O(1/K)$; 增加每个环境内的样本, 并不会在这个推导中消除有限环境数量的影响。若替换一个环境块引起的参数期望距离至多为 $s_{K,n}$, 损失又是 G -Lipschitz 的, 则同样可取 $\gamma_K \leq Gs_{K,n}$ 。

9.3.3 两类保证的比较与适用边界

逐目标域保证先固定一个允许目标域, 再要求训练得到的同一输出在该域上接近相应比较基准。共享标签机制与覆盖条件说明源域混合风险为何能够约束这个目标域; 若同一个高概率事件覆盖全部允许目标域, 还可以得到比逐域定义更强的同时保证。环境平均保证则把未来环境视为从 $\mathcal{Q}$ 抽取的随机对象, 评价的是共同假设在环境总体上的平均风险。它允许某些具体环境表现较差, 不能自动改写成对每个未见环境都有效。

两类保证中的样本量也承担不同作用。逐目标域路线依赖训练数据是否覆盖目标域所需的输入和标签机制; 环境平均路线则必须区分独立环境数量 K 与每个环境内的样本数 n 。增加 n 可以更准确地评价已见环境, 却不能替代新的独立环境。相应地, 普通样本稳定性控制环境内部的数据变化, 环境稳定性控制替换整个环境后的算法变化, 二者不能只因都称为稳定性便互换。

参数数量、范数和表示复杂度可以控制候选空间的估计误差, 参数稳定性可以控制算法对训练数据或训练环境的敏感程度, 但这些量都不能单独提供跨域联系。逐目标域保证仍需共享机制、覆盖和表示充分性, 环境平均保证仍需训练环境与未来环境来自同一环境分布。评价基准、跨域条件与有限样本控制共同决定结论能够推广到哪里。

9.4 前沿研究

前面得到的可学习性结论依赖明确的跨域结构: 目标域由源域覆盖、标签机制共享, 或者新环境与训练环境来自同一环境分布。预训练模型和持续变化的数据使这些条件更难直接验证, 也提出了新的理论问题。当前研究不仅需要更小的复杂度上界, 还需要解释预训练究竟保留了哪些目标信息, 以及哪些数据足以识别和检验这种联系。

9.4.1 预训练覆盖与表示充分性

大规模预训练之后，只调整少量参数就可能适应新的数据领域。这种现象不能仅用“可训练参数较少”解释。少量参数有助于减小预测头的估计误差，但前提是预训练表示已经保留目标域预测所需的信息。式(9.12)中的两项因此仍是分析起点：表示造成的目标域近似误差是否足够小，以及在固定该表示后还需要多少领域内数据才能控制估计误差。若表示与预测头共同由训练域数据选择，还须计算整个组合空间的复杂度，不能只统计最后调整的参数。

在本章固定输入空间、标签空间和预测任务的设定中，预训练数据可视作更早接触的一组源环境。理论需要说明这些环境是否覆盖目标域的重要输入，以及预训练形成的表示是否保留共享标签机制。参数范数、谱结构或参数分布可以控制有限样本误差，却不能替代这两项跨域条件。若改为源任务和目标任务不同，比较空间与风险定义也要随之改变，属于后续范式部分讨论的跨任务迁移。

大规模预训练还使“未见目标域”的含义需要重新检查。若预训练数据已经包含与目标域相近的环境，后续评价体现的可能是利用既有覆盖，而非超出全部训练环境的泛化。Mayilvahanan 等通过控制预训练中的领域信息研究这一问题，提示领域泛化评价需要把预训练阶段接触的分布也纳入说明⁸。

9.4.2 持续偏移下的可学习性

一次性从 $\mathcal{P}_S$ 迁移到 $\mathcal{P}_T$ 假定目标分布在评价期间保持固定。部署中的模型可能面对一串分布 $\mathcal{P}_1, \mathcal{P}_2, \dots$ ，一边观察数据一边更新参数。此时样本未必独立同分布，目标域也不再只有一个，期望风险需要带上时间索引。

理论必须同时限制环境变化和算法响应。若每一步的标签机制都能任意改变，过去观测不能保证下一步预测；若算法为了追踪变化而对少量新样本过度敏感，又可能放大噪声。因而需要把分布变化幅度、时间依赖、更新稳定性与恢复速度放进同一个保证。评价目标可以是各时刻超额期望风险之和，也可以是分布改变后恢复到给定误差水平所需的样本数量，但必须说明与哪个预测器比较。

Zhou 等关于测试时适应的近期预印本采用恢复复杂度视角，研究分布改变后适应过程恢复性能所需的代价⁹。这里需要区分用于更新模型的代理目标，与真正评价预测表现的任务目标。无标签数据可以计算某些代理损失，却不能直接给出真实标签下的任务损失。该工作的理论依赖局部区域中这两项目标的关系、光滑性或曲率条件，以及分布变化和时间依赖的限制。

这类结果的比较对象和适用区域需要保留在解释中。例如，接近局部代

⁸ P. Mayilvahanan, R. S. Zimmermann, T. Wiedemer, E. Rusak, A. Juhos, M. Bethge, W. Brendel, *In Search of Forgotten Domain Generalization* In Proceedings on “I Can’t Believe It’s Not Better: Challenges in Applied Deep Learning” at ICLR 2025 Workshops, 2025, pp. 90–130

⁹ Z. Zhou, M. Yang, S.-Y. Tian, K.-Y. Yu, L.-Z. Guo, Y.-F. Li, *On the Learnability of Test-Time Adaptation: A Recovery Complexity Perspective* In arXiv preprint arXiv:2605.28057, 2026

理目标最优点，不等于达到目标域全局贝叶斯风险；无标签代理目标下降，也不自动意味着真实分类期望风险下降。把定理 9.12 的稳定性保证扩展到依赖样本与变化分布，同时说明代理目标何时保留任务信息，是持续迁移可学习性中的核心问题。

9.4.3 有限监督下的预测保证

实际迁移中，覆盖常数、条件标签偏移和共同错误项往往未知。前面的定理明确给出了它们的作用，却没有保证它们都能由现有数据估计。进一步的理论需要回答：增加哪一种观测，才能把一个依赖未知条件的期望风险上界变成可验证的保证。

少量目标标签能够改变可识别性。例如，定理 9.3 中的困难来自无法知道 b 的标签，而不是假设数量过多；直接观察相关目标标签可以区分两个设定。一般问题则需定量分析目标标签数量、标签所在区域和偏移结构之间的关系。若只观察源模型的输出、无法访问原始源域样本，还需检查模型压缩后是否保留了估计跨域差异所需的信息。

风险控制也可以转向具有明确置信含义的预测输出。Wang 与 Qiao 在允许后验概率变化的广义协变量偏移设定下研究共形预测，利用规定的结构以及可用的带标签目标数据分析预测集合的覆盖性质¹⁰。这种保证评价真实标签落入预测集合的概率，与单一分类器的目标域期望风险或 PAC 可学习性不同。将覆盖、分类错误和标签成本放在同一问题设定中比较，才能说明增加监督实际换来了什么保证。

¹⁰ B. Wang, X. Qiao, *Conformal Prediction Under Generalized Covariate Shift with Posterior Drift* In Proceedings of the 28th International Conference on Artificial Intelligence and Statistics, 2025, pp. 4888–4896

9.5 本章小结

训练与使用分布不同时，目标域可学习性的首要条件是可观察的训练信息与目标域标签保持足够联系。即使假设空间只有两个成员，缺少覆盖或标签联系也可能使目标预测无法识别。因此，参数数量、范数与稳定性不能单独刻画迁移是否成功；它们控制有限样本学习的困难，跨域假设则决定这些信息能否用于目标域。

领域自适应允许观察目标域数据，但无标签数据只能直接说明输入分布。分歧距离和共同错误项把源域与目标域期望风险联系起来；协变量偏移配合覆盖条件，则能把目标域评价写成源域上的加权评价。在明确密度比是否已知、能否估计以及损失条件之后，VC 维、Rademacher 复杂度、PAC-Bayes 与稳定性才可给出相应的有限样本保证。一个仍含有不可控跨域残余项的期望风险上界，不能直接称为整个分布族上的 PAC 可学习性刻画。

领域泛化进一步取消训练时的目标域样本。定义 9.5 逐一固定允许的目标域，共享标签机制与覆盖为这种保证提供一条充分路径；定义 9.6 把训

训练环境与未来环境视为来自同一环境分布的独立抽样, 控制对新环境的平均表现。两者的评价对象和概率来源不同。增加每个环境内的观测数量, 通常不能代替增加独立训练环境的数量; 环境稳定性也必须与经验优化要求结合。

本章及本部分的可学习性结论只回答: 在给定观测、损失、比较空间和允许分布族后, 是否存在算法, 使任意误差容限 ϵ 与失败概率容限 δ 都对应一个统一的有限样本量门槛, 并对分布族中的每个允许分布以至少 $1-\delta$ 的概率使期望风险落入相应误差范围。它不判断所选损失是否覆盖真实使用后果, 也不判断比较基准对应的表现是否可接受; 对分布族之外的数据、系统组合或部署条件变化后的表现也没有自动保证。对于预训练、持续偏移与有限目标监督, 仍须先把可见信息、分布变化和比较对象写入学习问题; 这些对象尚未明确时, 更小的复杂度上界不能补足结论。

延伸阅读 Ben-David 等的领域自适应理论与不可学习性结果适合配合阅读。期望风险上界说明分布差异和共同预测能力各自起什么作用, 不可能性结果则说明缺少这些联系时, 为什么更多源域数据或无标签目标域数据仍可能不足。对照两类结论, 可以避免把某个上界中的复杂度项下降误认为整个迁移问题已经可学习¹¹。。

若希望继续研究参数分布如何参与跨域分析, 可阅读 Germain 等的 PAC-Bayes 领域自适应分解, 区分源域抽样误差、预测分歧变化与共同错误变化。这个视角也有助于检查哪些项能由无标签样本估计, 哪些项仍需关于标签机制的假设¹²。。

Maurer、Pontil 与 Romera-Paredes 对多任务表示学习的分析, 适合继续研究环境数量、环境内样本量与表示复杂度怎样共同影响学习。阅读时应保留其任务抽样与共享表示条件, 避免将对环境分布平均的保证解释成对任意新环境都成立的保证¹³。。

¹¹ S. Ben-David, J. Blitzer, K. Crammer, A. Kulesza, F. Pereira, J. W. Vaughan, *A Theory of Learning from Different Domains* In Machine Learning, 2010, vol. 79, pp. 151–175; S. Ben-David, T. Lu, T. Luu, D. Pál, *Impossibility Theorems for Domain Adaptation* In Proceedings of the Thirteenth International Conference on Artificial Intelligence and Statistics, 2010, pp. 129–136

¹² P. Germain, A. Habrard, F. Laviolette, E. Morvant, *An Improvement to the Domain Adaptation Bound in a PAC-Bayesian Context* In arXiv preprint arXiv:1501.03002, 2015

¹³ A. Maurer, M. Pontil, B. Romera-Paredes, *The Benefit of Multitask Representation Learning* In Journal of Machine Learning Research, 2016, vol. 17, no. 81, pp. 1–32

第三部分

机器学习可信性

Trustworthiness in Machine Learning

可信机器学习基础

上一部分讨论可学习性：在明确假设空间、损失、抽样关系和比较基准后，有限样本泛化保证说明，由样本得到的风险判断能够在多大误差和失败概率下推广到相应总体。这解决的是从有限样本到既定总体的统计推广问题。

从可学习性走向真实部署中的可使用性，还要把推广对象和使用条件说清。需要判断推广的是模型的预测误差、概率覆盖，还是模型、决策规则与使用流程共同造成的行动损失；也要回答受影响者能否质询决定并获得复核，以及数据、权限或流程变化后由谁发现失效、限制使用和执行补救。

一个邮件分类器在测试集上的准确率达到 97%，是否就可以让它自动删除被判为垃圾邮件的内容？如果它只负责把可疑邮件放入一个可恢复的文件夹，少量误判可能可以接受；如果它直接删除求职通知或合同附件，同样的误判率就可能造成更大的损失。即使有限样本保证支持它在某个总体上的误判率结论，也不能单独决定应当赋予隔离还是删除权限。

可信机器学习（trustworthy machine learning）研究模型及其使用过程满足合理使用要求的条件和证据。这里的可信性是相对于任务、受影响者和使用范围而言的。一个系统可以在概率预测上可靠，却泄露训练信息；也可以抵御某种攻击，却对少数群体持续产生较高的错误率。因此，可信性需要拆解为具体主张，再分别检验，而不能由一个笼统的综合得分代替。

本部分把讨论范围限定为技术可信性：考察由模型、数据、算法和技术系统证据支持的主张，并为组织审批、法律合规和公共治理提供可复核的输入。是否部署、由谁承担责任以及什么风险可以接受，仍需要有权主体结合领域规则和受影响者作出决定；技术测试通过不能替代这些判断，本部分也不声称完整覆盖人工智能治理。

本章从使用情境建立可信主张，再沿三个层次检查它：系统属性或规范要求说明必须满足什么，证据能力说明已有材料能够支持多强的结论，威胁与生命周期治理条件说明谁能使结论失效、由谁决定以及何时处置。无论考察可靠性、鲁棒性、公平性、行为约束、可解释性、隐私还是安全，核

心问题都是：在明确边界与剩余不确定性的前提下，已有证据可以支持系统承担多大范围的决策？

图 10.1 用交叉区域标出本书的技术范围。技术证据与其他判断可以讨论同一使用情境，却没有逻辑包含关系；技术检验通过，也不能推出某次部署已经合法、获准或得到公众认可。




图 10.1 技术可信性与法律合规、组织审批、公众治理的交叉范围。边界和交叉面积仅示意共享议题，不代表集合的度量、逻辑包含或职责继承。黄色轮廓标出本书着重讨论的技术证据范围，其他主体仍须依据自身适用要求作出判断。

10.1 技术可信性的范围与三个层次

风险分析需要先追踪模型输出怎样经由决策产生后果，再明确由谁承担这些后果、结论适用于什么范围。前者确定损失的含义，后者限定损失评价所针对的人和环境；缺少任一项，单个性能数值都无法支持使用判断。

可信性分析的起点是系统属性或规范要求，它回答系统在何种情境下必须满足什么。相应说明要写清受影响对象、评价单位和适用范围，再分别提出可靠性、鲁棒性、公平性、对齐、可解释性、隐私与安全要求。

要求明确后，需要考察证据能力：现有材料能够支持多强的结论。为此要说明显式假设、理论量词和抽样方式，并结合压力测试、机制分析与人因评价，记录反证和剩余不确定性。

证据结论还必须附带威胁与生命周期治理条件。分析要继续追问谁或什么能够使主张失效，谁负责决定，以及何时触发监测、限制使用、回退和恢复。

这三个层次相互依赖，却不能合并成一项指标。没有要求，测试结果不知道要支持哪种行动；没有证据，要求只是愿望；没有威胁和生命周期条件，一次通过的测试也会在数据、模型、权限或使用方式改变后被错误沿用。下面先用邮件系统明确情境与危害，再分别展开要求、证据和生命周期条件。

图 10.2 把三层问题与准备、复核和处置证据的人对应起来。分工不能由算法替代；实际项目还需在授权记录中写明每项责任由谁承担。




图 10.2 可信主张的三个层次。属性与规范明确必须满足什么，证据能力限定可以支持多强的结论，威胁与生命周期条件规定结论何时失效以及如何处置。三行分别对应任务责任方设定要求、技术人员论证与复核者检查边界、有权主体决定剩余风险与运行责任方处置。横线只表示同层对应；责任分工为教学示意，不能替代实际授权与审批程序。

10.1.1 从预测结果到实际后果

模型输出通常只是行动的一个输入。设输入为 $\mathbf{x}$ ，模型给出的结果为 $f(\mathbf{x})$ ，使用者或系统根据规则 d 选择行动 $a = d(f(\mathbf{x}), \mathbf{x})$ 。例如，分类器输出垃圾邮件概率，而决策规则可以选择放行、隔离或转交人工。即使 f 不变，改变 d 也会改变系统造成的后果。

为了比较这些后果，记真实状态为 y ，行动损失为 $L(a, y)$ 。相对于部署分布 $\mathcal{P}$ ，系统的期望损失为

$$R_{\text{sys}}(f, d) = \mathbb{E}_{(\mathbf{x}, y) \sim \mathcal{P}} L(d(f(\mathbf{x}), \mathbf{x}), y). \quad (10.1)$$

这个量同时依赖预测、决策规则和数据分布。用零一损失评价分类器，只计算是否预测错误；用行动损失评价系统，还要区分错误造成的代价。两种评价都可以有用，但回答的问题不同。

图 10.3 把预测与处置分开：改变决策规则时，模型可以保持不变，行动及其后果却会改变。




图 10.3 同一封正常邮件被误拦后的两种处置。预测 $p = f(x)$ 保持不变，上方隔离保留原件并允许找回，下方永久删除原件。末端收件人承担找回成本或错过期限的风险；真实状态 y 、发现延误与恢复成本仍须纳入 $L(a, y)$ 。图示为构造情景，不保证隔离后的邮件会及时找回。

示例 10.1 准确率与行动损失 考虑一个人为构造的 1000 封邮件测试集。模型甲误拦 10 封正常邮件、漏过 20 封垃圾邮件；模型乙误拦 2 封正常邮件、漏过 40 封垃圾邮件。甲的准确率为 97%，乙为 95.8%。若每次误拦损失为 10，每次漏过损失为 1，则甲的总损失为 $10 \times 10 + 20 = 120$ ，乙为 $2 \times 10 + 40 = 60$ 。在这一损失设定下，准确率较低的乙反而更适合使用。

示例中的代价由教学设定给出，并非邮件任务的普遍取值。实际使用还可能要考虑延误、申诉和恢复成本。若隔离后的邮件可以及时找回，损失可能小于永久删除；若用户不知道发生了误拦，可恢复性也未必转化为实际补救。这要求评价范围覆盖完整使用流程。

当模型输出概率时，决策规则可以由损失比较推导。设 p 确实表示给定输入为垃圾邮件的概率，误拦正常邮件的成本为 $c_{fp} > 0$ ，放过垃圾邮件的成本为 $c_{fn} > 0$ ，正确处理的成本暂设为零。隔离与放行的条件期望损失分别为 $(1 - p)c_{fp}$ 和 pc_{fn} ，因此选择隔离的条件是

$$p > \frac{c_{fp}}{c_{fp} + c_{fn}}. \quad (10.2)$$

相等时两种行动在当前损失模型下等价。阈值不是固定的 0.5：误拦越昂贵，支持隔离所需的概率就越高。这里的 p 是给定输入后的真实条件概率；把模型估计值代入，只能得到依赖估计质量的决策。即使若干概率区间中的平均预测与实际频率相符，也还不能断言每个输入的概率都准确。第 11 章将区分这些可靠性要求，并说明如何检验它们。

示例 10.2 增加复核选项后的决策 在一个教学设定中, 取 $c_{fp} = 10$ 、 $c_{fn} = 1$ 。若人工复核可以无误确认标签, 每次固定成本为 0.2, 则三项候选损失为 $10(1-p)$ 、 p 和 0.2。 $p < 0.2$ 时放行更合算, $p > 0.98$ 时隔离更合算, $0.2 < p < 0.98$ 时选择复核; 两个边界处分别有两种行动成本相同。这个区域来自行动成本的比较, 而不是模型额外输出了一个“犹豫”类别。

无误复核只是用于说明机制的简化条件。现实中人工也会出错, 复核成本可能随队列长度变化, 此时第三项必须包含这些后果。模型辅助决策的价值, 应与可行替代方案在同一条件下比较, 例如完全人工处理、简单规则或较低权限的自动化。只比较两个模型的准确率, 会遗漏它们是否优于现有流程这一更基本的问题。

成本难以精确确定时, 可以报告不同成本比下的决策变化。如果两种方案只在某个很窄的成本区间内有优势, 使用者就能识别结论依赖了哪项判断; 如果一个方案在相关区间中都更好, 选择依据更稳固。这类敏感性分析检查的是使用假设的变化, 应与第 12 章对输入和环境变化的分析区分。

预测损失与行动损失之间还可能隔着一个现实过程。若某个分数用于决定谁获得培训, 接受培训本身会改变后续成绩; 此时, 成绩不再是完全独立于决策的固定标签。只在过去获得培训的人中测得预测准确, 不能直接回答把名额分给其他人会产生什么收益。需要区分“预测现状”和“比较行动后果”, 并说明后者所需的额外观测或因果假设。式 (10.1) 把 y 视为不随当前行动变化的状态, 适合邮件真实类别这样的情形。若行动改变结果, 就需要描述不同候选行动下的可能结果, 再比较相应损失; 不能直接把历史行动下观察到的成绩当成所有行动共用的 y 。第 13 章讨论干预的长期影响时, 将再次遇到这一问题。

10.1.2 风险的承担者或使用范围

系统的购买者、操作人员和受影响者不一定是同一群体。招聘系统可能帮助用人方筛选简历, 却主要由求职者承受误拒后果。评价时应同时记录谁获得收益、谁承担错误、谁能够发现和纠正问题。只有开发者方便测量的指标, 未必覆盖这些不同影响。

风险还取决于使用范围。语言、设备、时间、输入质量和用户群体都可能改变模型的有效性。部署说明中的“适用于某类输入”, 应能对应到可检查的条件; 如果遇到范围外输入, 系统需要有识别、限制使用或转交的安排。第 12 章将讨论环境变化如何使已有规律失效。

失效不只来自预测错误。系统可能预测正确, 却暴露了私人信息; 可能忠实完成用户指令, 却执行了不被允许的动作; 也可能被外部内容诱导而

偏离任务。把这些后果写成具体情形，才能确定后续需要什么保护。NIST 的人工智能风险管理框架同样强调结合使用情境识别、测量和管理风险，但框架中的原则仍需落实为当前系统的具体要求¹。

10.2 系统属性与规范要求

要求的设定包含相互依赖的三步：把后果写成可判断的主张，检查这些主张是否遗漏重要情境，再处理不同要求之间的支持或冲突。一个可检验的要求，需要把希望避免的后果、能够观察的事件与决定行动的规则连起来。只有后果描述而没有可观察事件，无法判断系统是否改进；只有一个测量指标而没有行动含义，也可能优化了与使用目的无关的数值。

10.2.1 可信性要求的具体表达

“模型很可靠”没有说明可靠的对象。更明确的主张可以是：对规定分布中的邮件，自动隔离部分的正常邮件比例不超过某个阈值；或者，对指定人群给出的预测区间具有至少某个覆盖率。每条主张都需要标明评价单位、总体范围、错误事件和容许水平。

评价单位尤其容易被忽略。以单次请求为单位的失败率，与以用户一周的全部请求为单位的失败率不同。一个每次调用都很少出错的工具，在被连续调用后仍可能产生较高的累计失败概率。多步任务应同时检查单步性质与最终结果，不能把前者直接当成后者。

要求也不都适合写成平均损失。有些行为需要限制发生概率，有些要求需要对不同群体分别成立，还有些属于过程约束，例如敏感数据的访问必须受到授权。可以把目标概括为在满足约束的前提下选择模型与决策规则：

$$\min_{f,d} R_{\text{sys}}(f,d), \quad G_j(f,d) \leq b_j, \quad j = 1, \dots, m. \quad (10.3)$$

这里 G_j 是第 j 项可量化要求， b_j 是其容许水平， m 为要求数量。无法合理量化的程序要求仍需单独保留，不能为了套用公式而虚构分数。

10.2.2 可信性要求的完整性

即使已经约定风险，训练与验证也未必唯一确定了我们希望得到的行为。**欠规定性**（underspecification）指已有任务定义和评价条件允许多个表现近似相同的模型，却没有约束它们在实际关切上的差异。D’Amour 等在不同机器学习流程中展示了这一问题：训练域的留出表现接近，并不意味着部署时的行为可以互换。这将诊断对象从单个模型是否过拟合，扩展到整套训练和评价条件是否足以筛选模型²。

可以用一个构造例子看出二者的区别。设邮件训练数据中，内容特征

¹ National Institute of Standards and Technology, *Artificial Intelligence Risk Management Framework (AI RMF 1.0)*, tech. rep. NIST AI 100-1, National Institute of Standards and Technology, 2023

² A. D’Amour, K. Heller, D. Moldovan, B. Adlam, B. Alipanahi, A. Beutel, C. Chen, J. Deaton, J. Eisenstein, M. D. Hoffman, F. Hormozdiari, N. Houlsby, S. Hou, G. Jerfel, A. Karthikesalingam, M. Lucic, Y. Ma, C. McLean, D. Mincu, A. Mitani, A. Montanari, Z. Nado, V. Natarajan, C. Nielson, T. F. Osborne, R. Raman, K. Ramasamy,

x_1 与页脚特征 x_2 总是相同，且标签等于二者。使用 x_1 或 x_2 的分类器在独立同分布的测试集上都能完全正确；继续增加同一起来源的测试邮件，仍无法决定该信哪一条规律。如果部署后只有内容关系保持，两个模型便不再等价。这里缺少的是能区分候选规律的情境，单纯减少同一评价分布上的估计误差不能补上这类信息。

相应的改进也有两个层次。训练可以利用更多环境、结构约束或领域知识；评价则要主动设置能区分候选规律的测试。选择哪一层补充信息，取决于实际部署是否允许取得这些信息。不能因为某个随机种子碰巧在压力测试上表现较好，便把所有重新训练的模型都视为已通过同一验证。

另一种遗漏发生在类别内部。**隐藏分层** (hidden stratification) 指数据中存在与使用后果有关的子类型，却没有在标签或评价分组中表示。Oakden-Rayner 等的医学影像研究讨论了低频子类型、标注质量及伪相关怎样使总体表现掩盖重要子集的失败。其启示是检查现有标签是否描述了足够的任务差异，而不是认定所有自动聚类得到的组都具有实际意义³。

在邮件例子中，“正常邮件”可能同时包含普通通知和有截止日期的合同。即使两者的数量差异很大，使用者也可能更在意后者的漏读。应由任务后果提出候选切片，再核验每片的样本质量与统计不确定性。依据错误发现的新切片可以帮助诊断，但发现切片与确认切片需要区分，否则反复搜索后最差的一组可能只是抽样波动。鲁棒性与公平性两章将分别讨论环境切片和群体切片，本章先明确它们共同的出发点：总体指标不能代表未被表达的使用要求。

³ L. Oakden-Rayner, J. Dunnmon, G. Carneiro, C. Ré, *Hidden Stratification Causes Clinically Meaningful Failures in Machine Learning for Medical Imaging* In arXiv preprint arXiv:1909.12475, 2019

10.2.3 不同性质之间的联系与取舍

本部分讨论的性质对应不同问题。可靠性检查预测及其不确定性表达是否有依据；鲁棒性考察输入或环境变化后的有效性；公平性关注机会、错误与负担的分配；目标对齐与行为约束考察学习到的行为是否符合实际要求。可解释性提供理解和质疑这些行为的证据；隐私保护限制数据使用中的信息泄露；对抗安全进一步考察有人主动操纵系统时，这些边界能否保持。

这些性质可以相互支持，也可能产生取舍。例如，把更多输入转交人工可能降低自动处理部分的错误率，却减少自动处理比例；更严格的隐私保护可能增加统计估计的噪声；限制工具权限可能减少损害，也可能使任务无法完成。评价应报告同一使用目标下的变化，而不能只展示被优化的那一个指标。

将不同指标加权求和，还隐含了允许相互补偿的假设。如果未经授权披露数据属于不可接受行为，较高的准确率就不能自动抵消它。式 (10.3) 将约束与优化目标分开，正是为了明确这种区别。阈值和优先级需要由使用

目的、受影响者与领域知识共同确定，学习算法只能在给定要求下求解。

10.3 证据能支持什么结论

要求明确后，还需区分证据能支持多强的结论、如何取得有效证据，以及如何保留复核条件。这三个问题分别对应证据的含义、产生和记录。系统改变后原证据是否仍然适用，则属于下一节讨论的生命周期条件。

为了避免只记录一个有利分数，可以用十项内容组织一项**可信保证** (trustworthiness assurance)。这里的“保证”不是无条件承诺，而是一份可以逐项核对的论证记录。它先说明情境与危害，写清任务、受影响对象、评价单位和行动链；随后提出要求，明确指标或程序约束的分母、阈值和适用范围。

证据部分需要继续交代显式假设、论证、多源证据，以及反证与剩余不确定性。显式假设覆盖抽样关系、标签、权限、资源和替代方案；论证说明这些条件为何能支持要求，并保留量词与比较基准；多源证据可以来自理论、随机抽样、压力测试、机制分析、人因评价和监测；反证与剩余不确定性则记录失败案例、未覆盖情境、估计误差与替代解释。

最后四项把技术结论接入实际决策与生命周期管理。责任主体说明谁准备证据、作出决定、监测并执行处置；风险接受记录谁在什么范围、期限和不可补偿约束下承担剩余风险；失效触发指出哪些数据、模型、权限、流程变化或监测结果会暂停沿用原结论；处置则规定降级、停用、回退、通知、补救、复验与重新开放。威胁条件不另列一项，相关信息分别进入情境与危害、显式假设和失效触发；存在主动攻击者时，还要写明其知识、权限、资源、目标以及可能形成的损害路径。

10.3.1 理论保证与经验检验

理论保证解释在特定假设下必然成立的性质。它的力量来自量词和条件，而不是“有证明”这一标签。例如，一个覆盖保证可能对校准数据和未来样本的联合抽样成立，却不保证每个固定输入都具有相同覆盖率。使用保证时，需要检查数据生成方式、算法实现和实际评价对象是否与定理一致。

经验检验观察具体样本与攻击条件下的表现。它能够发现理论假设与现实之间的差距，也能够比较没有完整理论刻画的方法，但未观察到失效不等于证明失效不可能发生。下面的计算说明，即使评价设计很简单，也需要区分这两种结论。

示例 10.3 零次失败的含义 设固定系统面对 n 个独立同分布试验，每次失败概率为 p 。观察到零次失败的概率是 $(1-p)^n$ 。令 $(1-p)^n = \delta$,

可得到零失败结果对应的单侧置信上限

$$p_{\text{up}} = 1 - \delta^{1/n}.$$

在 95% 置信水平下, 100 次零失败对应的上限约为 2.95%, 1000 次零失败对应的上限约为 0.30%。这里的 95% 描述构造上限的统计程序在重复抽样中的覆盖性质, 不是给固定但未知的 p 赋予 95% 的后验概率。这些计算要求试验单位与抽样假设成立; 反复尝试直到出现一批零失败结果后再报告, 不能继续沿用同一解释。

10.3.2 检验设计与证据有效性

行为测试 (behavioral testing) 将“模型应当如何响应某种输入变化”写成可以执行的检查。Ribeiro 等提出的 CheckList 把语言能力与测试类型结合, 使评价不只依赖随机测试集的总准确率。它所组织的最小功能、保持不变和定向变化等检查, 帮助开发者把对行为的预期变成具体用例⁴。

沿用邮件任务, 可以从这三类预期构造测试。最小功能检查给出简短且含义明确的例子, 例如独立的会议通知; 保持不变的检查只改动大小写或无关排版, 要求正常邮件仍被放行; 定向变化则在任务已将某类未经请求的推销认定为垃圾邮件的前提下, 逐步加入明确的推销内容, 检查垃圾邮件分数是否朝预期方向变化。每项测试都依赖任务语义。将“转发诈骗警示中的诈骗原文”一律当成诈骗, 恰好会暴露模型没有区分引用与实际意图。

行为测试与随机抽样检验各有职责。前者可以有目的地暴露机制缺口, 后者可以在抽样假设下估计某个总体的风险。一个压力测试集故意大量收集困难样本, 其失败率一般不能直接当作部署失败率; 反过来, 在大规模普通样本上未发现某个低频缺陷, 也不足以免除针对它的检查。只有说明样本怎样取得, 数值才有相应解释。

模型选择、阈值调整和最终评价承担不同职责。如果根据测试结果反复修改模型, 原来的测试集就逐渐成为开发数据。需要保留未参与选择的数据, 或者使用能处理多次选择的统计方法。第 11.3 节将给出有限候选程序的一个简单保证。

比较两个系统时, 应尽量保持任务、样本、资源预算和评价口径一致。对于随机生成系统, 还需要记录生成次数、解码设置和选择规则。只挑选最好的回答与另一个系统的第一次回答比较, 会把额外计算和选择机会混入所谓模型优势。

人工或模型评判者也属于测量过程。需要检查其判断标准、重复一致性及与实际任务后果的关系。一个偏爱长回答的评判者, 可能提高冗长答案

⁴ M. T. Ribeiro, T. Wu, C. Guestrin, S. Singh, *Beyond Accuracy: Behavioral Testing of NLP Models with CheckList* In Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics, 2020, pp. 4902–4912

的得分，却没有提高事实正确率。评价证据应保存模型版本、数据来源、评价规则和必要的运行条件，使其他人能够复核结论。

10.3.3 证据的记录与复核

一个测试结果之所以能够被正确使用，往往依赖没有写在分数中的信息。测试数据是否包含重复记录、标签来自谁、哪些样本被排除、与预训练语料是否重合，都会影响结论。Gebru 等提出的 Datasheets for Datasets 主张随数据提供动机、组成、收集过程与推荐用途等说明，使数据使用者能够判断它与当前任务是否相容。这是一种记录数据条件的方式，本身并不证明数据没有偏差⁵。

模型也需要对应的说明。Mitchell 等提出 Model Cards，强调记录预期用途、评价过程以及相关群体或条件下的表现。它把一个笼统的模型名称具体化为具有版本、范围与证据的对象。模型卡可以承载本章所说的可信主张，但如果缺少真实评价，填写完整的卡片仍不能代替证据⁶。

二者的关系可以通过一次复核理解。邮件模型的记录称其正常邮件误拦率较低，但数据说明显示测试样本全部来自某一种语言和某个用户群体。复核者据此能发现，结论尚未覆盖另一种语言，而不是误把模型卡中的一个平均数理解为普遍承诺。如果之后补充了新的测试，更新的应当是具体覆盖范围和证据，不能只把模型版本号改掉。

记录还有助于区分不同复现目标。重新运行同一程序得到接近的数值，检查的是计算与随机性；用新的独立样本得到一致结论，检查的是跨独立样本的复现一致性；在新的环境中仍满足要求，检查的是外部适用性。三者扩大了复核范围，但相应结论并不相互推出。公开代码有助于第一项，对后两项仍需要合适数据及明确的环境联系。

对于生成系统，保存一个最终回答尤其不够。模型版本、系统提示、检索内容、工具权限、采样温度、重试次数与答案选择方式都可能改变输出分布。若比较时名义上只考察模型变化，实际却同时增加了重试机会，观测到的收益应归于整个过程，不能全部解释为模型能力提高。这些条件应随评价结果一起保存，也应出现在之后的重新验证中。

10.4 威胁与生命周期治理条件

前两层说明“希望系统做到什么”和“现有证据支持到哪里”，还没有回答这些结论怎样随系统一起使用。生命周期条件需要记录哪些参与者、环境变化或系统组件可能使结论失效，谁有权接受剩余风险，哪些观测触发限制使用，以及怎样恢复到可以再次评价的状态。本章说明审批、监测和复查需要哪些技术材料，但不替组织规定法定职责，也不替受影响者决定什么后果可以接受。

⁵ T. Gebru, J. Morgenstern, B. Vecchione, J. W. Vaughan, H. Wallach, H. Daumé III, K. Crawford, *Datasheets for Datasets* In arXiv preprint arXiv:1803.09010, 2021

⁶ M. Mitchell, S. Wu, A. Zaldivar, P. Barnes, L. Vasserman, B. Hutchinson, E. Spitzer, I. D. Raji, T. Gebru, *Model Cards for Model Reporting* In Proceedings of the Conference on Fairness, Accountability, and Transparency, 2019

10.4.1 威胁条件、责任主体与风险接受

威胁条件不只指恶意攻击。数据来源变化、标注流程失真、供应商更新、权限扩大、人员负荷和组件故障，都可能破坏保证所依赖的条件。需要记录变化能够作用在哪个对象、通过什么路径影响要求，以及现有监测能否发现。有人主动选择这些变化以造成损害时，还要加入其知识、权限、资源和目标；这些条件共同构成分析主动攻击时的威胁模型。

责任主体 (accountable role) 是对保证中的某项决定或行动负有明确职责的角色。准备评价、独立复核、批准使用、运行监测和事故处置可以由不同角色承担；只写“项目组负责”会让触发后无人知道谁能停用系统。

风险接受 (risk acceptance) 则是在已知证据边界和剩余不确定性的前提下，由有权主体决定某项残余风险是否能在规定范围与期限内承担。它不是证明风险消失，也不能让一个指标的收益抵消已经声明为不可接受的约束违反。

10.4.2 变更触发与组合后的重新验证

一个组件满足要求，并不意味着组件组合后仍满足同样要求。检索器返回的内容可能改变生成模型的输入分布，自动重试可能扩大隐私泄露机会，人工审核也可能因告警过多而失效。重新验证应围绕这些新关系展开，而不只是重复组件测试。

可信主张因而需要附带**失效触发** (invalidation trigger)：哪些数据变化、权限扩大、模型更新或监测结果会暂停沿用原结论。记录这些条件并不削弱结论，反而使使用者知道何时能够依赖它。组织如何审批、发布和追责属于更完整的治理流程；技术材料至少要暴露决策点、所需证据和触发条件，使这些流程能够作出有依据的判断。

系统组合还可能改变错误之间的依赖关系。假设在同一垃圾邮件总体上，两个检测器各有 10% 的漏检率，并且任一个报警就能拦截邮件。只有在这一总体上两个漏检事件独立的条件下，才能把系统的共同漏检率算成 1%。若它们使用同一表征并遗漏同一类邮件，共同漏检率可能仍为 10%。设置第二个检测器的价值因此要看它是否提供新的信息，而不能只看它在结构上是否“多了一层”。

人工复核也需要同样处理。人看到的可能是原始证据，也可能只是模型生成的摘要；摘要已经遗漏关键信息时，增加确认步骤未必纠正错误。若要主张人机协作降低了风险，应评价真实的协作过程，包括复核者能看到什么、需要处理多少告警，以及是否有时间采取行动。第 14.2 节将进一步把这些要求落实到行为监督。

10.4.3 失效处置与恢复

触发失效后，处置目标是先限制损害，再保存足以定位问题的证据，随后恢复到可以重新评价的状态。根据危害类型，可以暂停自动动作、降低权限、切换到人工流程、回退模型或隔离数据；已经删除的内容、已经泄露的信息和仍可撤销的状态具有不同恢复边界，不能统一写成“回滚即可”。处置还应说明如何通知受影响者、如何纠正已有结果，以及哪些日志必须在满足隐私与访问约束的条件下保留。

重新开放不是原版本再次启动，而是对触发原因和修复范围重新建立证据。复验应包含已知失败的回归检查，也要检查修复是否改变正常任务、其他群体或相邻性质。责任主体据此重新判断剩余风险；若证据仍不足，就应继续限制使用或选择危害更小的替代流程。监测、处置与恢复因此不是部署后的附加步骤，而是保证成立条件的一部分。

10.5 例子：邮件隔离的完整保证记录

前三节已经分别说明如何设定要求、评价证据并管理结论的生命周期。下面沿用章首邮件系统，把这些要素合并为一个完整的教学验收实例。模型、样本、阈值和结果均为人工构造，只用于展示怎样形成可判定的保证记录，不能当作真实邮件服务的经验数据。实例固定模型版本 v_1 及其概率修正程序 c_1 ，适用于公司自有网关在批准后 30 日内接收的中文或英文文本邮件；加密正文、纯图像邮件和从网关外导入的邮件不在范围内。误拦可能延误合同与求职通知，漏放可能使用户接触诈骗内容，系统因此不获得永久删除权限。规则在 $p < 0.2$ 时放行，在 $0.2 \leq p \leq 0.98$ 时转人工复核，在 $p > 0.98$ 时进入可恢复隔离。

独立验收集包含 600 封正常邮件和 400 封垃圾邮件。规则隔离 362 封，其中 2 封为正常邮件；转人工 100 封，其中 70 封为正常邮件；放行 538 封，其中 10 封为垃圾邮件。验收要求隔离量不少于 300 封、自动隔离比例不低于 30%，且以隔离邮件为分母的正常邮件比例，其单侧 95% 二项 Clopper-Pearson 置信上界不超过 2%。当前点估计为 $2/362 \approx 0.55\%$ ，置信上界约为 1.73%，自动隔离比例为 36.2%，三项均达到规定阈值。50 次恢复演练从用户点击“恢复”计时，直到邮件同时出现在收件箱和搜索索引中；第 95 百分位为 3 分钟，最大值为 7 分钟，分别低于 5 分钟和 10 分钟的限制。

这项结论显式假定验收集与 30 日适用范围具有约定的抽样关系，标签可靠， v_1 、 c_1 和两个阈值在验收前固定，人工队列可用，隔离区和搜索索引均支持恢复。论证由四个环节组成：行动损失确定三段规则，范围检查限制自动处理对象，非零最低隔离量与置信上界控制抽样不确定性，恢复演练检验补救路径。除总体计数外，中英文各有 500 封邮件，每组隔离 181

封并误拦 1 封；40 项预先规定的行为压力测试也全部通过。

这些证据仍留下明确缺口。10 封垃圾邮件被放行，新式模板、隐藏子类型、共同训练盲点和人工复核错误仍可能使系统失效；低频重要邮件的估计区间可能较宽，目前也没有真实上线监测结果。评价人员负责冻结验收集并计算上界，产品责任人批准范围与有效期，运行人员负责监测、停用和回退，用户则能够查看隔离结果并发起恢复。根据上述结果，教学实例中的产品责任人接受 v_1 在规定范围内运行 30 日，只允许可恢复隔离，不接受永久删除；隐私或安全约束失败时，也不得由较高准确率抵消。

模型、修正程序、阈值、标签规则或工具权限一旦改变，邮件超出声明范围，隔离量低于 300 封、比例低于 30%、置信上界或恢复时延越界，人工队列不可用，或者出现攻击与泄露迹象，原结论就停止适用。此时应暂停自动隔离并转入人工流程，回退到已验证版本，恢复误拦邮件并保留事件记录；补充评价和处置证据，经责任主体重新接受后再逐步开放。

10.6 本章小结

章首的邮件分类器不能仅凭准确率决定是否自动删除邮件。三个层次把这个问题拆开：系统属性或规范要求规定自动处理的范围、错误分母和不可补偿约束；证据能力说明独立样本、压力测试与机制检查能够支持什么；威胁与生命周期条件则规定由谁接受剩余风险，哪些变化触发停用，以及怎样恢复。前面的教学实例据此只支持有条件、可恢复的自动隔离，并不支持永久删除。其中 2% 上限以被隔离邮件为分母，与以全部正常邮件为分母的误拦率不同；两者若都影响使用决定，就必须分别记录。

不同性质回答的问题并不相同。可靠性检查概率与风险承诺是否得到数据支持，并讨论何时把输入转交其他流程；鲁棒性处理规定变化下的有效性，公平性检查机会、错误与负担的分配；目标对齐与行为约束、可解释性、隐私保护和对抗安全分别补充行为边界、解释证据、信息保护与主动攻击条件。它们可以相互提供证据，却不能由某项改进替代其余要求。

技术可信性最终形成的是一组有边界、可复核且带处置条件的主张，而不是一个综合标签。技术证据可以揭示系统在哪些条件下达到要求、还留下哪些不确定性，并为审批和复查提供输入；它不能替代组织对职责的安排、法律判断或受影响者参与的公共治理决定。

延伸阅读 NIST 人工智能风险管理框架适合继续理解使用情境、测量和风险处置之间的关系；阅读时应把框架原则落实为具体系统中的责任主体、证据和失效触发，而不是只保留抽象分类⁷。

若希望进一步建立可复核的技术记录，可对照数据集说明书与模型卡。前者强调数据的动机、组成和采集条件，后者强调模型的预期用途与分组

⁷ National Institute of Standards and Technology, *Artificial Intelligence Risk Management Framework (AI RMF 1.0)*, tech. rep. NIST AI 100-1, National Institute of Standards and Technology, 2023

评价；二者都帮助限定证据范围，却不能替代实际测试⁸。

⁸ T. Gebru, J. Morgenstern, B. Vecchione, J. W. Vaughan, H. Wallach, H. Daumé III, K. Crawford, *Datasheets for Datasets* In arXiv preprint arXiv:1803.09010, 2021; M. Mitchell, S. Wu, A. Zaldivar, P. Barnes, L. Vasserman, B. Hutchinson, E. Spitzer, I. D. Raji, T. Gebru, *Model Cards for Model Reporting* In Proceedings of the Conference on Fairness, Accountability, and Transparency, 2019

第 11 章

可靠性

邮件分类器报告“垃圾邮件概率为 0.9”，使用者可能据此自动隔离邮件。但 0.9 究竟代表什么：在相似情形中大约九成是垃圾邮件，还是模型内部的一个较大分数？如果换成一段生成式回答，某个词的概率很高，又能否说明整段内容正确？要依赖不确定性输出，需要先明确它描述的事件，再检验它与实际结果的关系。

本章讨论的**可靠性** (reliability)，是指模型在约定的使用条件下，预测及据此作出的决策能否满足明确的质量与风险要求。要求可以落在概率的频率含义、预测范围的覆盖程度，或自动处理的损失上。判断可靠性需要同时说明这些要求和成立的条件，不能只给模型一个笼统的“可信”评分。

在第 10 章的三层架构中，可靠性主要属于系统属性或规范要求层：系统需要明确概率、预测范围或自动决策应达到什么标准。校准、覆盖和决策风险的检验与保证位于证据能力层，用来判断这些标准得到多强的支持。抽样关系、模型版本、阈值或反馈条件一旦改变，原结论可能失效，因而还要在威胁与生命周期治理层规定复验与限制使用的触发条件。

不确定性输出为这一判断提供线索：模型是否知道自己可能出错，所给范围是否反映尚未确定的结果。但线索本身也可能失真。第 11.1 节说明不确定性的来源与估计；第 11.2 节从输出的数值含义、决策用途和适用范围检验这些估计；第 11.3 节再讨论如何在明确假设下构造满足覆盖或决策风险要求的程序。估计回答模型表达了什么，检验回答这种表达是否得到数据支持，保证则回答什么条件能够支持进一步的使用承诺。

图 11.1 把可靠性问题放回邮件处理场景：证据足够时按规则自动隔离，证据不足时转交复核。图标只是当前教学情景中的不同线索，不能把“带有宣传内容”直接当成垃圾邮件的判据。分流是否有价值，要在第 11.2.2 节同时检查自动处理的比例与接受部分的风险。




图 11.1 按判断依据分配自动处理与复核。单个标记表示当前规则接受的判断，两个不同形状的标记表示仍待辨别的候选；上方邮件进入可恢复的隔离文件夹，下方交给人工。此图引入邮件处理情景，分流本身不证明可靠，也不假定人工无误；处理比例与选择性风险的计数见图 11.4。

11.1 不确定性的来源与估计

可靠性需要相对于具体要求判断：概率是否有可信的频率含义、预测范围是否覆盖实际结果、采用预测作出的决策是否满足风险限制。不确定性描述模型对结果尚有多大把握，是建立这些判断的起点，却不等于可靠性本身。

模型不能确定结果，可能是当前信息不足以唯一决定结果，也可能是有限训练数据尚未让模型学会已有规律。这两种来源需要分别刻画：前者考察给定输入时结果仍有多大波动，后者考察仍有哪些不同模型与已知数据相容。本节先建立这一区分，再讨论两类来源的估计方法；这些估计是否兑现其含义，留到下一节用独立数据检验。

11.1.1 不确定性的来源

设输入为 $\mathbf{x}$ ，目标为 y ，已有训练数据为 D 。即使输入完全相同，结果也可能不同。例如，现有邮件特征没有包含发送者的真实意图，相同文本可能出现在正常通知和诈骗邮件中。相对于当前观测，仍然存在的结果随机性称为**偶然不确定性**（aleatoric uncertainty）。它不一定在增加观测信息后仍不可减少。

另一种不确定性来自知识不足：有限数据可能支持多个不同预测模型。补充相关样本后，模型之间的分歧可能减小，这通常称为**认知不确定性**（epistemic uncertainty）。两者是相对于观测和模型假设的区分，不能仅由

一次预测分数唯一识别。

对邮件分类器，可以固定可见特征来理解这一区别。一种情况是同样的文字既可能出现在正常通知中，也可能被用于诈骗；即使充分掌握这类文字的统计规律，仅凭这些特征仍无法唯一判断。另一种情况是某种新语言的训练邮件很少，多个模型对相同内容给出不同判断；增加有标签的相关邮件，可能减少这部分知识不足。前者需要表达给定信息下的结果分布，后者需要表达对预测规律的把握程度。

区分来源并不意味着能直接测出各自大小。真实条件分布通常未知，模型还可能遗漏重要因素，因此实践中得到的是依赖模型假设的估计。参数后验、模型集成和条件分布学习都是建立这种估计的手段；它们本身不构成新的不确定性类别。近似计算也会产生误差，但这种估计误差应与被估计的不确定性分开。

图 11.2 固定邮件任务比较两种信息缺口：左侧缺少区分真实意图的特征，右侧缺少能够约束候选模型的相关数据。增加同一类训练记录可能减少后者，却不自动补上前者缺少的观测信息。




图 11.2 偶然不确定性与认知不确定性的区别。左侧同一可见特征可能对应正常通知或诈骗意图，固定模型也需表达结果分布；右侧相关样本不足，三个候选模型给出不同预测， p_m 简写 $p_m(y=1|x)$ 。概率 0.2、0.5、0.8 为教学构造，条长示意预测分歧，不是实测值或后验抽样。两种来源均相对于当前观测与模型假设而言。

11.1.2 认知不确定性的估计

对于知识不足，仅保留一个拟合结果会隐藏其他可能的解释。估计认知不确定性的一个思路，是保留多个与数据相容的模型，观察它们对同一输入是否给出相同预测。参数可以相差很大而预测相同，因此与决策有关的是预测分歧，不能只看参数数值的离散程度。

在贝叶斯建模中，设 θ 为模型参数， $p(\theta|D)$ 为参数后验，预测分布通

过积分得到

$$p(y | \mathbf{x}, D) = \int p(y | \mathbf{x}, \theta) p(\theta | D) d\theta. \quad (11.1)$$

每个候选参数给出一个条件预测，后验权重表达数据对候选参数的支持。对于二阶矩存在的实值目标，全方差公式进一步给出

$$\begin{aligned} \text{Var}(y | \mathbf{x}, D) &= \mathbb{E}_{\theta|D} \text{Var}(y | \mathbf{x}, \theta) \\ &\quad + \text{Var}_{\theta|D} \mathbb{E}(y | \mathbf{x}, \theta). \end{aligned} \quad (11.2)$$

第一项平均各模型内部的结果波动，对应所建模型中的偶然不确定性；第二项刻画各模型预测均值的分歧，对应参数知识不足带来的预测方差。这里把总预测方差拆成两个来源，而不是把总方差都称为认知不确定性。这个分解在给定的概率模型中成立，却不证明模型已经包含现实中全部不确定性。若所有候选模型都遗漏同一个因素，第二项很小也可能伴随系统性错误。

式 (11.1) 说明了理想的计算对象，却没有解决计算困难。深度网络的参数很多，后验通常无法直接积分。若只保留使后验密度最大的一个参数，预测就忽略了其他仍与数据相容的解释。实际方法需要在计算预算内，保留一部分参数不确定性。

一种做法是用容易抽样的分布 $q_{\phi}(\theta)$ 逼近后验，其中 ϕ 控制近似分布。最小化 q_{ϕ} 到后验的 KL 散度，等价于最小化

$$\mathcal{J}(\phi) = -\mathbb{E}_{q_{\phi}} \log p(D | \theta) + \text{KL}(q_{\phi}(\theta) \| p(\theta)). \quad (11.3)$$

第一项要求抽出的模型解释数据，第二项限制近似分布偏离先验的程度；被省略的 $\log p(D)$ 与 ϕ 无关。这种近似把难积分的问题转成优化问题，但近似族可能过于狭窄。例如，彼此独立的单峰参数分布未必能表达多种相距很远的解释。优化收敛也不能消除近似族本身的限制。

Gal 和 Ghahramani 从这一思路解释了特定设置下的 dropout 训练，并提出在预测时保留随机失活、进行多次前向计算来估计不确定性。这一方法通常称为**蒙特卡洛失活** (Monte Carlo dropout, MC dropout)：同一输入经过不同随机掩码，产生多个预测，再用这些预测近似积分。它复用了常见训练机制，但贝叶斯解释依赖相应的近似模型与正则化设置，不能把任意已有网络随意打开 dropout 所得的波动都当成正确后验¹。

若进行 M 次前向计算，第 m 次得到类别分布 $p_m(y | \mathbf{x})$ ，其平均 $\bar{p}(y | \mathbf{x}) = M^{-1} \sum_{m=1}^M p_m(y | \mathbf{x})$ 近似预测分布。增加 M 可以减小给定近似分布下的蒙特卡洛误差，却不能修正先验、似然或近似族的错误。对延迟敏感的系统，还需要将重复前向计算的成本与拒答带来的收益一同评价。

另一条路径不要求显式近似参数后验，而是保留多个独立优化得到的模型。**深度集成** (deep ensembles) 对多个网络的预测分布求平均，用模

¹ Y. Gal, Z. Ghahramani, *Dropout as a Bayesian Approximation: Representing Model Uncertainty in Deep Learning* In Proceedings of the 33rd International Conference on Machine Learning, 2016, pp. 1050–1059

型之间的分歧补充单个网络的输出。Lakshminarayanan 等将独立初始化、概率评分训练与集成预测结合，为深度网络提供了易于实现和并行训练的不确定性基线²。

对于第 m 个回归模型，设输出均值 $\mu_m(\mathbf{x})$ 和方差 $v_m(\mathbf{x})$ 。等权混合的均值与方差为

$$\begin{aligned}\bar{\mu}(\mathbf{x}) &= \frac{1}{M} \sum_{m=1}^M \mu_m(\mathbf{x}), \\ \bar{v}(\mathbf{x}) &= \frac{1}{M} \sum_{m=1}^M v_m(\mathbf{x}) + \frac{1}{M} \sum_{m=1}^M (\mu_m(\mathbf{x}) - \bar{\mu}(\mathbf{x}))^2.\end{aligned}\tag{11.4}$$

这正是混合分布的全方差分解。作为教学例子，两个模型的预测均值为 0 和 2，方差均为 1，混合均值便是 1，方差为 $1 + 1 = 2$ 。只平均方差会漏掉均值分歧；只计算均值分歧又会漏掉各模型内部的结果波动。

集成成员独立初始化，不意味着它们的错误在现实数据上相互独立。相同训练集、架构和损失可能诱发共同的盲点。多个模型一致地给出错误答案时，集成分歧仍然很小。因此，MC dropout 与深度集成主要提供可计算的概率表达和分歧信号，其价值要由校准、拒答效果及分布变化下的检验确认。

11.1.3 偶然不确定性的刻画

上一小节改变候选模型，观察预测是否一致；这里固定一个候选模型，考察它认为同一输入下结果还可能怎样变化。这对应式 (11.2) 中的模型内部波动。分类任务可以输出类别概率，回归任务则需要给出条件分布或预测范围。对于输入相关的噪声，可以同时学习条件均值和条件方差；若只关心结果落在哪个范围内，也可以直接拟合分位点，而不指定完整分布。

若假定 $y | \mathbf{x}$ 服从均值 $\mu(\mathbf{x})$ 、方差 $v(\mathbf{x}) > 0$ 的正态分布，忽略常数后的单样本负对数似然为

$$\frac{(y - \mu(\mathbf{x}))^2}{2v(\mathbf{x})} + \frac{1}{2} \log v(\mathbf{x}).$$

增大方差可以降低大残差的第一项，却会增大第二项；两个部分共同约束模型，避免通过无限放大方差解释一切误差。不过，单个正态分布难以表达多峰结果。如果一封邮件可能属于两种完全不同的处理路径，用一个中间均值和很大的方差概括，未必适合后续决策。

不愿完整指定分布形状时，可以直接学习所需分位点。对 $\tau \in (0, 1)$ ，**分位数损失** (pinball loss) 写为

$$\rho_\tau(u) = u(\tau - \mathbf{1}\{u < 0\}), \quad u = y - q_\tau(\mathbf{x}).$$

² B. Lakshminarayanan, A. Pritzel, C. Blundell, *Simple and Scalable Predictive Uncertainty Estimation using Deep Ensembles* In *Advances in Neural Information Processing Systems*, 2017

在损失期望存在时，按真实分布最小化该期望，会得到一个 τ 分位点：目标值不大于该位置的概率至少为 τ ，不小于该位置的概率至少为 $1 - \tau$ 。高分位点对低估惩罚更重，低分位点对高估惩罚更重。训练上下两个分位点即可形成随输入变化的区间，但有限数据、模型限制和优化误差都可能使实际覆盖偏离目标，后面需要独立校准补上这一环。

这些方法估计的是给定输入时的结果波动，但学习到的方差和分位点本身也会受知识不足影响，不能把一个网络输出的方差直接视为真实偶然不确定性。若把多个候选模型的结果分布混合，最终预测范围就同时反映模型内部波动和模型间分歧，仍需在未用于拟合的数据上检查。预测区间覆盖的是未来目标；参数置信区间或可信区间描述的是参数信息。将参数区间代入一个预测值，并不一定覆盖额外的结果噪声。

对生成模型，概率对象尤其重要。设回答为词元序列 $(w_1, \dots, w_T)$ ，其概率是条件词元概率的乘积。这个概率衡量模型偏好生成该序列的程度，不能直接当作陈述真实的概率。语义相同的答案还可能有许多表达方式。评价时应确定对象是一个事实主张、一个完整答案，还是完成任务的最终结果，再选择相应评分。

11.2 可靠性的检验

得到概率、区间或分歧分数之后，需要用已知结果检验它们。检验先从输出的数值含义入手，例如报告 0.9 的事件是否约有九成发生。

数值含义得到支持，仍不能说明分数适合决策。还要检查它能否找出较高风险的预测，使拒答确实降低自动处理风险。

上述证据如果只在总体上成立，仍可能掩盖重要群体或使用条件中的失败，因此还要在这些局部条件下复测。前两个角度分别评价输出本身和输出的决策用途，这一角度则检查前两类证据的适用范围，并不是另造一个综合分数。

三类检验都需要职责明确的数据。模型拟合、概率修正和阈值选择应在最终测试之前完成，不能在测试结果中反复选择有利设置后，仍将它们当作独立评价。生成任务还应固定正确性定义、评判者和采样规则。事实是否有来源、是否被来源支持、是否在现实中正确，是不同判断，不能只用字符串匹配覆盖全部要求。本节的“检验”包括指标估计与诊断；涉及达标与否的统计结论时，还需要给出抽样条件与估计误差。

11.2.1 概率与预测范围的检验

不确定性小意味着模型给出的范围集中，并不意味着范围的位置正确。反过来，一个覆盖所有可能标签的集合可以永远覆盖真实标签，却无法帮助选择行动。因此，可靠性既需要符合承诺，也需要保留足够的信息量。




图 11.3 校准性与区分能力的区别。左侧实线是理想校准关系，虚线是构造的过度自信曲线，二者不来自实验。右侧假设两个等大群体的正例比例分别为 20% 和 80%；始终输出 0.5 的预测器在总体上校准，按组输出 0.2 与 0.8 的预测器同样校准，却能区分两组的风险。

对二分类，令 $y \in \{0, 1\}$ ， $p(\mathbf{x})$ 为预测事件 $y = 1$ 的概率。若

$$\mathbb{E}[y | p(\mathbf{x})] = p(\mathbf{x}) \quad \text{几乎处处成立,} \quad (11.5)$$

则称概率预测具有**校准性** (calibration)。它表示具有相同预测概率的样本，在总体中有对应的事件频率。连续分数下，条件期望的表述避免了把零概率事件直接当作普通频率计算。

一个始终输出总体正例比例的预测器也可能校准，却不能区分不同输入。校准性与区分能力需要分别检查；同样，平均覆盖、个体信息量和决策损失也承担不同职责。Guo 等对现代神经网络校准性的研究说明，较好的分类表现并不自动带来恰当的概率表达³。

图 11.3 展示了这种区别。即使概率与总体频率相符，也仍要检查分数能否区分具有不同风险的输入。

概率校准的经验修正 若分类排序较好而概率偏大，可以在独立校准数据上拟合后处理参数。例如，温度缩放用正数 t 调整未归一化类别对数分数 $z_k(\mathbf{x})$ (logit)：

$$p_t(y = k | \mathbf{x}) = \frac{\exp(z_k(\mathbf{x})/t)}{\sum_j \exp(z_j(\mathbf{x})/t)}.$$

在校准数据上最小化负对数损失可以选择 t 。正温度不改变同一输入中类别分数的大小顺序，因此保留最大概率类别，却改变概率的集中程度。若系统按固定概率阈值隔离邮件或拒答，实际行动仍可能改变，需要重新检验第 10.1 节中的行动损失。该过程改善的是数据支持下的概率表达，本身不提供任意新分布下的校准保证。

³ C. Guo, G. Pleiss, Y. Sun, K. Q. Weinberger, *On Calibration of Modern Neural Networks* In Proceedings of the 34th International Conference on Machine Learning, 2017, pp. 1321–1330

当 $t > 1$ 时, 分数差被缩小, 分布变得平缓; 当 $0 < t < 1$ 时, 分布更集中。一个参数使方法不易在小校准集上过拟合, 但也限制了能修复的错误: 某些类别过度自信、另一些类别不足自信时, 单一温度未必足够。更灵活的类别相关变换或单调映射能够修正更复杂偏差, 却增加估计难度, 甚至改变原有决策边界。选择复杂度应由独立评价支持, 不能仅看校准集损失。

这一角度检验模型所报数值与实际结果是否相符。对概率, 比较预测概率与事件频率, 并评价整份概率分布的质量; 对集合或区间, 比较名义覆盖率与实际覆盖率, 同时检查范围是否过宽。二者都在检验输出表达的内容, 尚未回答用这些输出筛选输入能否降低决策损失。

实际数据中可以将预测概率划分为若干区间, 比较每个区间的平均预测概率与实际正例比例, 这构成可靠性图。若第 b 个非空区间包含 n_b 个样本, 平均预测为 $\bar{p}_b$ 、正例比例为 $\bar{y}_b$, 则一个分箱校准误差为

$$\widehat{\text{ECE}} = \sum_{b=1}^B \frac{n_b}{n} |\bar{p}_b - \bar{y}_b|. \quad (11.6)$$

这里 B 为区间数, n 为总样本数。区间太粗可能把相反偏差抵消, 太细又会使频率估计不稳定。报告该值时应同时说明分箱和样本量, 不能把不同口径的数值直接排序。

概率评分还可以使用负对数损失或 Brier 分数。二分类 Brier 分数为 $n^{-1} \sum_i (p(\mathbf{x}_i) - y_i)^2$ 。若真实条件概率为 $\eta(\mathbf{x})$, 固定输入后有

$$\mathbb{E}[(p - y)^2 | \mathbf{x}] = (p - \eta)^2 + \eta(1 - \eta).$$

第二项与预测 p 无关, 因此期望分数在 $p = \eta$ 处最小。这说明评分具有鼓励真实概率的性质, 但样本上的平均分数仍混合了校准与区分能力, 不能取代分组诊断。

这种在真实分布处达到最优的评分称为**适当评分规则** (proper scoring rule); 当最优分布唯一时, 称为严格适当。对类别概率向量 $\mathbf{p}$, 负对数损失的条件期望可分解为真实分布的熵加上真实分布到 $\mathbf{p}$ 的 KL 散度。因此, 训练时把概率说得过于绝对, 会在低概率事件真的发生时付出很大损失。Brier 分数有界, 对极端错误概率的惩罚则较温和。两者关注的仍然是概率质量, 不能直接替代漏掉一封重要邮件的实际损失。

多分类下还要说明检验的是哪一种校准。若只比较最大类别概率与预测正确率, 检验的是最高分预测的校准; 逐类别检验则比较每个类别概率与相应标签频率。完整概率向量的校准要求在同一预测向量下, 所有类别的实际比例均匹配预测。后者更强, 也更需要数据。仅看最高分概率可能遗漏其余类别间的系统性偏差, 而这些偏差会影响代价敏感决策和预测集合。

可靠性图应在每个区间同时展示样本支持。假设某个高置信区间只有 10 封邮件，模型平均概率为 0.9，实际其中 9 封为垃圾邮件；这不是对 0.9 的精确确认。相同的 9/10 可能来自较宽范围的总体概率。扩大校准数据、使用明确的二项比例区间或预先规定分箱，能让读者看见估计的不确定性。不能为了得到漂亮的可靠性图，在看到结果后反复合并不利区间。

对于预测集合 $C(\mathbf{x})$ ，用 $\mathbf{1}\{y \in C(\mathbf{x})\}$ 的样本平均估计覆盖率；同时报告集合大小，回归区间则报告长度。若系统承诺 90% 覆盖，观察到某批数据中 90% 的目标落入范围，只是经验结果，还需要考虑抽样误差。总体覆盖也不能直接说明每个群体或每类输入具有相同覆盖。

示例 11.1 校准与区分能力 在一个正例比例为 10% 的构造总体中，预测器甲对所有输入都报告 0.1，因此满足总体上的概率校准。预测器乙能够将样本分为两类，并分别给出与实际频率一致的 0.02 和 0.5。令两类占比分别为 5/6 和 1/6，总体正例比例仍为 $(5/6) \times 0.02 + (1/6) \times 0.5 = 0.1$ 。乙同样校准，却提供了更多区分信息。仅凭“校准误差小”不能判断哪一个更适合筛选高风险输入。

11.2.2 风险识别与拒答效果的检验

概率数值不够准确的分数，也可能把易错样本排在前面；反过来，总体校准的常数概率不能区分哪些输入更危险。因此，需要直接检验不确定性与实际损失的关系。这里固定预测模型和不确定性分数，观察拒绝较不确定的输入后，留下部分的损失是否降低，以及为此放弃了多少自动处理。

若系统允许拒答，可以用接受函数 $g(\mathbf{x}) \in \{0, 1\}$ 表示是否自动处理。记损失为 $\ell(f(\mathbf{x}), y)$ ，则处理比例与接受部分的风险分别为

$$\begin{aligned} c(g) &= \mathbb{P}(g(\mathbf{x}) = 1), \\ R_{\text{sel}}(f, g) &= \frac{\mathbb{E}[\ell(f(\mathbf{x}), y)g(\mathbf{x})]}{c(g)}, \quad c(g) > 0. \end{aligned} \quad (11.7)$$

实际检验时，令 $u(\mathbf{x})$ 为数值越大表示越不确定的分数，按阈值 t 设 $g_t(\mathbf{x}) = \mathbf{1}\{u(\mathbf{x}) \leq t\}$ 。在独立测试集上同时记录分数、预测和真实标签，计算

$$\begin{aligned} \hat{c}(t) &= \frac{1}{n} \sum_{i=1}^n g_t(\mathbf{x}_i), \\ \hat{R}_{\text{sel}}(t) &= \frac{\sum_{i=1}^n \ell(f(\mathbf{x}_i), y_i) g_t(\mathbf{x}_i)}{\sum_{i=1}^n g_t(\mathbf{x}_i)}. \end{aligned} \quad (11.8)$$

第二式只在接受样本数为正时定义。改变阈值并画出 $(\hat{c}(t), \hat{R}_{\text{sel}}(t))$ ，就得到风险—处理比例曲线。在相同处理比例下，风险越低，说明这次测试中分数越能将高损失输入留给其他处理方式。比较时可以加入不利用分数的

随机拒答参照，避免把减少工作量本身误认为识别风险的能力。

示例 11.2 相同拒答比例下的不同效果 假设十封测试邮件中有两封被分错，使用零一损失。分数甲把这两封排为最不确定，拒绝它们后自动处理八封，经验风险为 0。分数乙却把两封预测正确的邮件排为最不确定，同样处理八封时风险为 $2/8 = 25\%$ ，高于全部处理时的 20%。若随机拒绝两封，留下八封的期望错误率仍为 20%。这个构造例子检验的是分数与错误的对应关系，与分数是否具有校准的概率含义不同。

图 11.4 把同一批邮件按两种分数分别排序，接受区中的编号直接对应式 (11.8) 的分母。两种分数都让八封邮件进入接受区，但其中保留下来的错误数不同。因此，减少自动处理只有在分数确实识别了错误时，才会改善这次测试的接受部分风险。




图 11.4 选择性预测的处理比例与风险。沿用示例 11.2 的十封邮件，× 标出错误的 9 与 10 号，✓ 标出正确预测；两行按不确定性递增排列。蓝色区接受八封，灰色区拒绝两封。 $\hat{c}(t)$ 以全部邮件为分母， $\hat{R}_{\text{sel}}(t)$ 以接受邮件为分母，分别估计 $c(g_t)$ 与 $R_{\text{sel}}(f, g_t)$ 。样本零风险不保证总体风险为零。

曲线用于比较筛选能力，具体使用承诺还需检验实际采用的工作点。例如，在验证集上确定阈值后，固定该阈值，在独立测试集上报告接受样本数、条件风险及其区间估计。样本中零错误不等于总体风险为零；接受样本太少时，即使曲线点看起来很好，也可能不足以支持目标风险要求。把测试曲线上最有利的一点直接选作部署阈值，会重新引入选择偏差。

图 11.5 进一步计算两种排序的全部十个工作点。随着接受范围扩大，甲直到第九封才纳入错误，乙从第一封就纳入错误；两条曲线在全部接受时回到相同的 $2/10$ 。曲线走向取决于具体排序，不能预先假定筛选后的风险一定随阈值单调变化。




图 11.5 同一十封邮件上的风险—处理比例曲线。采用图 11.4 的完整排序，对接受 1 至 10 封分别计算经验风险；空心圆为甲，三角形与虚线为乙。80% 处理比例对应 0 与 25% 风险，全部处理时两者均为 20%。每个点都是教学计数的精确比例，不含测量误差；接受零封时风险无定义，因此不画零处理比例的数据点。

这种允许模型只处理部分输入的设置称为**选择性预测** (selective prediction)。其最简单实现是按最大类别概率设阈值，但概率最大的样本未必是行动风险最小的样本。若误删正常邮件的代价高于放过垃圾邮件，接受规则应考虑类别及代价；同一个 0.9，对“自动隔离”和“提醒用户检查”可能支持不同决策。

作为理想参照，设自动预测的条件期望损失为 $r(\mathbf{x})$ ，拒答并转人工的固定代价为 c_r ，且人工处理没有额外错误。沿用示例 10.2 中的成本比较，逐输入最小化损失会在 $r(\mathbf{x}) \leq c_r$ 时自动处理。若使用零一损失、知道真实类别概率，且自动预测选择概率最大的类别，则 $r(\mathbf{x}) = 1 - \max_k p(y = k | \mathbf{x})$ ，最大概率阈值才由这一特殊假设得到。人工也会犯错或拥堵时，拒答代价应随输入和负载变化。

评价分母必须写清。若系统处理 100 个请求中的 10 个，并在其中错 1 个，接受部分错误率为 10%，全体请求中“接受且错误”的比例为 1%。降低处理比例可以使后一项很小，却未必使前一项足够小。拒答后的人工损失和延迟也应纳入完整决策评价。

11.2.3 局部条件下的检验

前两类检验如果只对全部测试数据求平均，仍可能掩盖某种语言或使用情境中的失败。这里保持已经声明的使用范围不变，只把概率质量、覆盖率和选择性风险放回重要子群体中重新计算，判断总体结论适用于哪些人群和条件。因而它与前两小节是总体证据和条件化证据的关系，并不是第三种互不相干的可靠性指标。

具体做法是根据使用要求，预先规定语言、设备、时间或任务类型等切片。设某个切片为 S ，测试集中属于该切片的索引集合为 I_S ，样本数为

$n_S = |I_S| > 0$ 。对于预测集合 $C(\mathbf{x})$ ，组内经验覆盖率为

$$\widehat{\text{Cov}}_S = \frac{1}{n_S} \sum_{i \in I_S} \mathbf{1}\{y_i \in C(\mathbf{x}_i)\}. \quad (11.9)$$

将这一数值与组内要求的覆盖水平比较，同时报告样本数、区间长度或集合大小以及覆盖率的区间估计。检验概率校准时，在组内重新比较预测概率与事件频率；检验拒答时，在组内计算处理比例和接受部分风险。后一项的分母必须是该组被接受的样本数，不能用全组样本数替代。若没有接受样本，就没有这组自动处理风险的直接经验估计。

一个构造例子可以说明这一检验的必要性。假设测试集含 900 封常用语言邮件和 100 封少见语言邮件，模型预测集合分别覆盖其中 846 封和 54 封。总体覆盖率恰为 $900/1000 = 90\%$ ，两组却分别为 94% 和 54%。若要求每种语言都达到 90% 覆盖，总体结果没有检验到这项要求；还需判断各组覆盖的估计误差。可靠性图或风险—处理比例曲线也可能出现相同的平均掩盖问题。

组内样本越少，估计越不稳定。报告宽置信区间意味着证据不足，不能将点估计相近解释为表现相同。切片很多时，偶然波动也会带来极端结果；根据已经看到的错误临时挑出的切片，可以用于发现问题，但达标判断需要新的独立复核或适当的多重比较处理。检验有限组也不等于检验每一个输入的条件可靠性。

切片必须仍属于原可信主张覆盖的总体。若评价对象改成新的时间、来源、设备或扰动强度，数据与未来输入之间的关系已经改变，问题就不再只是总体指标是否掩盖局部失败，还需要重新说明变化范围及其任务含义。下一章将统一处理这类环境变化，并同时检查预测风险、不确定性输出和拒答机制是否失效。

三类检验合起来才能支持具体判断：概率或范围兑现数值含义，不确定性能够帮助减少自动处理损失，而且这些性质在所关心的条件中都有证据。任一项失败都能指出需要修正的环节；全部通过也只是在相应数据与误差范围内获得支持，不能直接升级为任意未来输入的保证。

11.3 可靠性的保证

前一节从样本检验已有程序，本节进一步回答：怎样构造程序，使它在明确条件下满足预先规定的可靠性要求？需要先确定承诺的对象和成立条件，再分别建立预测范围的覆盖保证与决策程序的风险保证。前者既包括可交换数据下的一次预测，也包括依靠连续反馈维护的长期覆盖；后者直接约束程序采取行动造成的损失。两类保证控制的事件不同，不能相互代替。

11.3.1 保证对象与成立条件

保证必须同时说明三件事：控制什么事件，依赖什么数据关系，以及概率针对什么随机对象。例如，真实结果落在预测集合内，是覆盖事件；系统自动处理请求造成的代价，是决策损失。覆盖率达标不表示集合足够小，也不直接限制从集合中任意挑选一个答案后的错误率。拒答降低自动处理部分的风险，也不表示全部请求的处理成本都下降。

独立同分布、可交换性和可观察的连续反馈，支持的是不同类型的结论。它们不是可以从训练损失较低推出的性质，需要由数据取得方式与使用流程支持。构造方法则负责把这些条件转化为承诺：共形方法利用校准分数的秩，风险上界利用经验损失的集中性质，在线方法利用反馈误差的累积关系。下面将分别给出这些联系。

还应区分保证中的概率量词。边际覆盖的概率同时对随机校准样本和新样本取平均；期望风险则把未来数据上的损失平均成一个总体量。高概率风险控制还对随机验证集提出要求：对绝大多数验证集，由此选出的程序都应满足规定的总体风险上界。边际结论可以允许少数校准集产生覆盖较差的程序，只要联合平均达到要求；高概率结论则为程序的验证结果增加一层置信要求，通常需要更多数据或更保守的选择。报告“有保证”时，应把每一层概率针对什么随机对象写完整。

11.3.2 预测范围的覆盖保证

可交换数据下的边际覆盖 如果使用要求是覆盖真实结果，可以直接构造集合。**共形预测** (conformal prediction) 根据校准样本中预测偏差的排序，确定新样本的接受范围。它允许使用已经训练好的模型作为评分器，覆盖有效性来自抽样与排序条件，而不要求基础模型的概率已经校准⁴。

校准这个词在此有两个相近但不同的用法。概率校准要求数值与事件频率匹配；共形校准则用留出样本的分数选取集合阈值，目标是覆盖。一个概率仍不准确的模型，可以经过共形校准得到有效但较大的集合；一个概率评分很好的模型，在校准数据与测试数据关系错误时，也可能失去集合覆盖保证。

设固定评分函数 $s(\mathbf{x}, y)$ ，值越大表示候选结果与模型越不相符。评分函数的训练数据与校准数据分开。对 n 个校准样本计算 $s_i = s(\mathbf{x}_i, y_i)$ ，给定 $\alpha \in (0, 1)$ ，令

$$k = \lceil (n+1)(1-\alpha) \rceil, \quad C_\alpha(\mathbf{x}) = \{y : s(\mathbf{x}, y) \leq q\}, \quad (11.10)$$

其中 $k \leq n$ 时 q 是校准分数的第 k 个顺序统计量， $k = n+1$ 时约定 $q = +\infty$ 。这一约定使样本不足以支持很高覆盖时，程序仍然有效，只是输出可能没有区分力。

⁴ A. N. Angelopoulos, S. Bates, *A Gentle Introduction to Conformal Prediction and Distribution-Free Uncertainty Quantification* In arXiv preprint arXiv:2107.07511, 2022

定理 11.3 分割共形预测的边际覆盖 在给定训练所得评分函数后, 若 n 个校准样本与一个新样本可交换, 即其联合分布对样本顺序的置换不变, 则式 (11.10) 满足

$$\mathbb{P}(y_{n+1} \in C_\alpha(\mathbf{x}_{n+1})) \geq 1 - \alpha.$$

概率同时涉及校准样本和新样本; 并列分数按所给闭集合规则处理。

证明. 没有并列时, 新分数在 $n+1$ 个分数中的秩由交换性均匀分布。新分数不超过校准分数第 k 位, 等价于它在合并样本中的秩不超过 k , 其概率为 $k/(n+1) \geq 1 - \alpha$ 。存在并列时, 可以先随机打破并列进行同样比较; 把边界上的全部并列分数纳入集合, 只会增加覆盖概率。 $k = n+1$ 时集合接受所有候选结果, 结论直接成立。■

回归中可以取 $s(\mathbf{x}, y) = |y - f(\mathbf{x})|$, 得到区间 $[f(\mathbf{x}) - q, f(\mathbf{x}) + q]$ 。分类中可取 $s(\mathbf{x}, y) = 1 - p(y | \mathbf{x})$, 保留偏差不超过 q 的类别。评分越能反映局部难度, 相同覆盖目标下的集合越可能有用, 但较小集合仍需实际比较。

这个定理不保证每个固定输入都有 $1 - \alpha$ 覆盖, 也不保证每一批固定校准数据都产生同样好的条件覆盖。分组构造需要足够组内样本; 变化环境下则需要额外的分布联系或不同的在线目标。将“分布无关”理解成不需要任何数据关系, 会误用保证。

图 11.6 将评分函数的训练、校准排序和新输入的集合构造分开。覆盖承诺依赖校准样本与新样本的交换性, 不能从图中区间的宽度直接读出。

自适应范围与条件覆盖边界 边际覆盖建立后, 还有两个需要分别回答的问题: 集合能否随输入难度调整, 以及能否把覆盖承诺落实到局部人群。前者关乎信息量, 后者关乎保证范围; 区间宽度自适应并不能自动解决后者。

固定宽度区间容易在低噪声区域过宽、在高噪声区域过窄。Romano、Patterson 和 Candès 提出**共形分位数回归** (conformalized quantile regression, CQR), 把前面学习到的上下分位点作为区间形状, 再用共形分数修正覆盖⁵。

具体地, 先在训练集上拟合下、上分位点 $\hat{q}_l(\mathbf{x})$ 和 $\hat{q}_u(\mathbf{x})$, 并保证两者顺序正确。校准分数取为

$$s(\mathbf{x}, y) = \max\{\hat{q}_l(\mathbf{x}) - y, y - \hat{q}_u(\mathbf{x})\}. \quad (11.11)$$

目标落在原区间外时, 分数是越界距离; 落在内部时, 分数非正。按

⁵ Y. Romano, E. Patterson, E. J. Candès, *Conformalized Quantile Regression* In arXiv preprint arXiv:1905.03222, 2019




图 11.6 分割共形预测的构造。评分函数先由独立训练数据确定，再用校准分数选择阈值。图中采用教学残差 0.1, 0.2, ..., 0.9，取 $n = 9$ 、 $\alpha = 0.2$ ，故 $k = 8$ 、 $q = 0.8$ ；绝对残差评分产生右侧回归区间。数值说明排序与集合构造，不是覆盖率的实验测量。

式 (11.10) 得到分位阈值 q 后，校准区间为

$$[\hat{q}_l(\mathbf{x}) - q, \hat{q}_u(\mathbf{x}) + q].$$

正 q 扩张原区间，负 q 则允许收缩，必要时集合可以为空。有限样本边际覆盖来自相同的排序论证，不需要分位数模型拟合正确；区间是否短而有用，则依赖基础分位点能否反映局部噪声。

假设两个输入的原始区间分别为 $[8, 12]$ 和 $[0, 20]$ ，共形修正值为 2，校准后区间就是 $[6, 14]$ 和 $[-2, 22]$ 。二者共享同一覆盖修正，却保留不同难度对应的宽度。这说明“有效性不依赖模型正确”与“效率依赖模型质量”能够同时成立。它仍不表示两个输入各自都获得规定的条件覆盖。

分类问题也需要让集合随难度变化。Romano、Sesia 和 Candès 研究按类别概率的累计质量构造自适应预测集合：高概率类别集中时，只需少数类别；概率分散时，应保留更多可能性⁶。

例如，将类别按概率从大到小排序，候选类别的分数可以取截至该类别的累计概率，再使用独立样本校准阈值；原方法还通过随机化处理边界类别。若只按固定单类概率设阈值，不同输入上被排除的总概率质量可能差异很大。累计质量评分改善这一点，但基础概率错误时，仍只能依赖共形步骤提供边际有效性，不能把自适应集合误读成逐输入保证。

为何不能继续要求每个输入都准确覆盖？Barber 等研究了无分布假设的条件预测推断限制：在足够一般的连续输入、实值输出问题中，要对所

⁶ Y. Romano, M. Sesia, E. Candès, *Classification with Valid and Adaptive Coverage* In *Advances in Neural Information Processing Systems*, 2020

有分布提供非平凡的精确条件覆盖，存在根本障碍⁷。

困难来自有限样本无法识别每个细小邻域中的结果分布。两个总体可以在所有已观察数据附近表现相同，却在尚未充分观察的输入区域有不同的尾部。若区间必须同时保护所有可能总体，就可能不得不变得极宽。增加神经网络规模无法自动解除这一信息限制；必须增加平滑性或分布假设，或放宽保证对象。

一种可行放宽是预先规定有限群体，在每个群体内单独校准；另一种是要求在一族受限切片上近似满足覆盖。群体越细，局部有效性越有针对性，但每组样本越少，集合也越保守。对预先规定的组，组内交换性支持相应组内覆盖；对看完错误再挑出的任意子组，不能直接沿用同一个论证。这一差别将在公平性章节再次出现：总体的好表现不能替代对特定受影响群体的证据。

变化环境中的长期覆盖 部署后不断得到新标签时，固定阈值未必适合持续变化的数据。Gibbs 和 Candès 提出**自适应共形推断** (adaptive conformal inference, ACI)，用已经观察到的覆盖错误更新下一轮的名义错误水平，目标转向长期覆盖频率⁸。

令目标错误比例为 α ，第 t 轮内部使用的名义水平为 $a^{(t)}$ ，实际未覆盖指示为 $e_t = \mathbf{1}\{y_t \notin C_t(\mathbf{x}_t)\}$ 。一个基本更新为

$$a^{(t+1)} = a^{(t)} + \gamma(\alpha - e_t), \quad \gamma > 0. \quad (11.12)$$

发生未覆盖时， $a^{(t)}$ 减小，下一轮要求更高覆盖，集合趋于扩大；覆盖成功时则逐渐提高名义错误水平。将递推式相加可得

$$\frac{1}{T} \sum_{t=1}^T e_t - \alpha = \frac{a^{(1)} - a^{(T+1)}}{\gamma T}.$$

只要内部状态始终有界，右侧就随 T 增大而趋于零。这是反馈控制的代数性质，并不要求每一轮数据独立同分布。

有界性不能被略去。原方法把分位数函数扩展到通常概率范围之外：名义错误水平小于 0 时允许输出全集，大于 1 时允许输出空集，以把更新推回范围。不能随意将 $a^{(t)}$ 截断到 $[0, 1]$ 后，仍直接套用上面的无截断恒等式。全集和空集也说明了保证的代价：长期比例正确，未必意味着每轮集合都有用。

学习率 γ 决定反馈速度。较大值能更快响应变化，也带来更剧烈的集合波动；较小值更平稳，但可能在突变后恢复较慢。标签延迟、只有被接受样本才有反馈，或错误集中发生在某类输入时，还需要重新分析可观察性和目标。长期平均覆盖不能保护任意短时间窗口，更不能直接保证某一封

⁷ R. F. Barber, E. J. Candès, A. Ramdas, R. J. Tibshirani, *The Limits of Distribution-Free Conditional Predictive Inference* In arXiv preprint arXiv:1903.04684, 2020

⁸ I. Gibbs, E. Candès, *Adaptive Conformal Inference Under Distribution Shift* In arXiv preprint arXiv:2106.00170, 2021

高损失邮件处理正确。

11.3.3 决策程序的风险保证

上一小节保证真实结果进入集合，实际系统却还需要决定采取什么行动。覆盖错误只是任务损失的一种。共形风险控制将分割共形的思想推广到满足规定单调性和有界条件的损失族，控制相应期望风险；它与对校准集以高概率成立的风险上界具有不同的量词⁹。

固定候选程序的高概率风险界 要理解高概率风险保证，可以从有限候选程序的选择开始。将预测器、接受阈值和拒答规则合起来视为一个程序；每个程序都在独立验证前固定，再用统一置信上界判断哪些程序可以投入使用。设 K 个程序在验证前固定，第 j 个程序的损失 L_j 取值于 $[0, 1]$ ，总体风险为 $R_j = \mathbb{E}[L_j]$ ，验证样本独立同分布。记经验损失为 $\hat{R}_j$ ，则 Hoeffding 不等式与联合界给出

$$\mathbb{P}\left(\forall j, R_j \leq \hat{R}_j + \sqrt{\frac{\log(K/\delta)}{2n}}\right) \geq 1 - \delta. \quad (11.13)$$

因为每个程序违反其上界的概率至多为 δ/K ，全部违反事件的概率之和不超过 δ 。因此，可以在上界不超过目标风险的程序中，选择自动处理比例最高的一个。若没有程序达标，应报告证据不足或改变处理策略，而不应只选经验风险最小者并宣称达标。

这一保证需要候选程序没有利用同一验证集任意生成。对零一预测损失，拒答若被计为零损失，上界控制的是全体请求中接受且出错的概率；这与式 (11.7) 中以接受请求为分母的条件风险不同。完整系统也可以把拒答成本纳入 L_j ，在归一化到 $[0, 1]$ 后比较风险与服务能力。

自动处理部分的条件风险界 若使用要求明确针对自动处理部分，可以同时控制分子与分母。令第 j 个固定程序的接受指示为 $A_j(\mathbf{x}) \in \{0, 1\}$ ，其预测损失为 $\ell_j \in [0, 1]$ ，记验证集上的联合损失均值为 $\hat{J}_j = n^{-1} \sum_i A_j(\mathbf{x}_i) \ell_j(\mathbf{x}_i, y_i)$ ，接受比例为 $\hat{c}_j = n^{-1} \sum_i A_j(\mathbf{x}_i)$ 。对 K 个分子的上界和 K 个分母的下界同时应用集中不等式，令 $b_n = \sqrt{\log(2K/\delta)/(2n)}$ ，则至少 $1 - \delta$ 的概率，对所有满足 $\hat{c}_j > b_n$ 的候选程序都有

$$R_{\text{sel},j} = \frac{\mathbb{E}[A_j \ell_j]}{\mathbb{E}[A_j]} \leq \min\left\{1, \frac{\hat{J}_j + b_n}{\hat{c}_j - b_n}\right\}. \quad (11.14)$$

这给出了按条件风险筛选程序的一种保守办法。接受比例很小时，分母下界接近零，保证会变弱； $\hat{c}_j \leq b_n$ 时，这一构造无法给出有用的条件风险上界。它不是模型一定不可靠的证明，而是当前样本和界不足以支持该承

⁹ A. Angelopoulos, S. Bates, A. Fisch, L. Lei, T. Schuster, *Conformal Risk Control In International Conference on Learning Representations*, 2024

诺。扩大独立验证样本、改变接受规则或采用更适合该损失的置信界，才能进一步缩小证据缺口。

候选程序的构造与独立验证 这一上界说明怎样筛选程序，却没有保证候选集合中一定存在足够好的程序。要扩大可行选择，还需在独立训练阶段构造更好的候选对象。候选程序既可以是固定预测器配上不同接受阈值，也可以通过训练联合学习预测与拒答。仅对现有分数设阈值，未必能得到适合筛选高风险输入的表示。Geifman 和 El-Yaniv 提出的 SelectiveNet 把预测与选择联合训练，直接优化接受区域上的表现，而非仅在训练结束后按置信度截断¹⁰。

为了理解这类目标，令 $g_i \in [0, 1]$ 为样本的软接受权重， ℓ_i 为预测损失，目标处理比例为 c_0 ，可以考察

$$\frac{\sum_i g_i \ell_i}{\sum_i g_i} + \lambda \left(\max \left\{ 0, c_0 - \frac{1}{n} \sum_i g_i \right\} \right)^2, \quad (11.15)$$

其中 $\lambda > 0$ ，并要求分母为正。第一项鼓励留下易于可靠处理的输入，第二项惩罚处理比例不足。为了避免网络在特征尚未学好时就只关注一个狭小子集，SelectiveNet 还使用辅助预测头，在全部训练样本上学习同一预测任务，再将辅助损失与选择性损失加权结合。这是训练目标，而不是测试条件风险保证；模型仍需在独立数据上选择实际阈值并验证风险。

因此，训练、验证和选择各有职责：训练改善候选程序的风险与处理能力，独立验证构造上界，选择规则在同时有效的上界中确定可用程序。若看到验证结果后继续训练新候选，就已经改变了保证所依赖的数据关系，需要新的验证数据或另行处理这种适应性。

11.3.4 两类保证的比较与适用边界

预测范围保证把输出对象设为集合 $C(\mathbf{x})$ ，控制真实结果未落入集合的事件。集合大小或区间长度决定这一保证是否仍有信息量，却不属于覆盖率本身。决策风险保证则把预测器、接受规则和后续行动合成一个程序，直接控制事先定义的损失。它可以把误判、拒答成本或其他行动后果纳入同一风险对象，却不要求程序一定输出预测集合。

保证对象并不决定概率量词和数据条件；同一种覆盖或风险对象，在不同数据制度下也可能对应不同结论。本节选取的分割共形预测在校准样本与新样本可交换时提供边际覆盖，自适应共形推断在可观察反馈和有界内部状态下控制长期未覆盖频率，有限候选程序的高概率风险界则依赖独立同分布的验证样本，并对验证集的抽取给出置信要求。这些结论分别回答一次预测、长期序列和程序验证中的问题，不能只按数值大小比较强弱。

¹⁰ Y. Geifman, R. El-Yaniv, *SelectiveNet: A Deep Neural Network with an Integrated Reject Option* In Proceedings of the 36th International Conference on Machine Learning, 2019, pp. 2151–2159

预测集合可以作为决策程序的输入，但覆盖保证不会自动变成行动风险保证。要从前者推出后者，还需说明程序怎样使用集合，以及覆盖失败、集合过大和拒答分别造成什么损失。反过来，一个通过独立验证的低风险程序也未必给出具有频率含义的概率或覆盖集合。实际选择保证时，应从使用承诺出发：需要容纳真实结果，就规定覆盖事件和范围效率；需要限制自动处理的后果，就规定行动损失和处理比例；两项都需要时，应分别建立并检验，不能用一个指标替代另一个。

11.4 前沿研究

11.4.1 从词元变化到语义不确定性

生成回答的表述变化与知识分歧并不相同。对同一个问题，“巴黎”和“法国首都是巴黎”是不同序列，却可能表达同一答案；如果直接对字符串概率计算熵，就可能把表达多样性当作事实不确定性。Kuhn 等提出在语义层面对等价回答合并概率，为语言生成的不确定性建立了与表述变化相区分的对象¹¹。

设回答序列为 w ，输入问题为 $\mathbf{x}$ ，语义等价关系将回答划分成类别 $S_1, \dots, S_J$ 。理想的语义类别概率为 $\pi_j = \sum_{w \in S_j} p(w | \mathbf{x})$ ，相应的**语义熵** (semantic entropy) 为

$$H_{\text{sem}}(\mathbf{x}) = - \sum_{j=1}^J \pi_j \log \pi_j. \quad (11.16)$$

它计算的是模型在不同含义之间的分散程度。实际不能穷举回答空间，通常采样多个回答，再借助语义等价或双向蕴含判断聚类，因此得到的仍是受采样和语义判断误差影响的估计。

作为构造例子，四个等概率回答若都表达“巴黎”，字符串熵为 $\log 4$ ，合并后语义熵为 0；若两个回答表达“巴黎”、两个表达“里昂”，语义熵为 $\log 2$ 。第二种情形暴露了答案内容的分歧，而第一种主要是措辞变化。但如果四个回答都坚定地给出同一个错误城市，语义熵仍为 0。低语义熵只能说明含义稳定，不能作为真实性证明。

Farquhar 等进一步将语义熵用于检测生成模型中任意而错误的回答，重点识别会随采样变化的虚构内容。这个目标比检测所有不真实陈述更窄：稳定的错误知识、系统性偏见或误导性问题可能不表现为高语义熵¹²。

多次生成和语义聚类带来额外成本。Kossen 等研究从单次生成的内部表示预测语义熵，用训练好的探针近似昂贵的多次采样过程。由此得到的是低成本风险信号，迁移到新模型、领域或解码设置时，仍需检查该信号与目标错误之间的关系¹³。

¹¹ L. Kuhn, Y. Gal, S. Farquhar, *Semantic Uncertainty: Linguistic Invariances for Uncertainty Estimation in Natural Language Generation* In International Conference on Learning Representations, 2023

¹² S. Farquhar, J. Kossen, L. Kuhn, Y. Gal, *Detecting Hallucinations in Large Language Models Using Semantic Entropy* In Nature, 2024, vol. 630, pp. 625–630

¹³ J. Kossen, J. Han, M. Razzak, L. Schut, S. Malik, Y. Gal, *Semantic Entropy Probes: Robust and Cheap Hallucination Detection in LLMs* In arXiv preprint arXiv:2406.15927, 2024

11.4.2 开放生成中的风险对象与保证

生成任务使可靠性的对象从一个标签扩展到一组语义主张。同一个答案可以部分正确，评判者也可能判断错误；若把有偏的评判结果当成真实标签，统计保证最多约束该评判规则下的损失。因此，生成式风险控制需要同时说明目标损失、可观察替代量和它们之间的联系。

Conf-Gen 把共形风险控制扩展到生成任务，并在其规定条件下研究图像记忆、澄清提问与智能体输出等对象。它的意义是将“生成质量”拆成可定义的风险事件，而不是为任何开放回答提供逐条真实性证明¹⁴。

持续变化环境又削弱了固定校准集与未来样本之间的联系。加权方法需要可估计的分布比或结构假设，自适应方法可能追求长期平均覆盖。后者即使成立，也允许某一段时间集中失效。对于连续调用的智能体，局部覆盖还需与任务中的选择、重试和依赖关系结合，这使评价单位成为研究设计的一部分。

这也改变了“可靠生成”的实验单位。若一个系统先生成多个答案、挑选一个、再检索并修订，最终需要检验的是整个程序的输出，而不是任一中间模型的一次回答。用原始单次生成数据校准的阈值，未必适用于经过筛选的输出。提高采样预算还可能增加找到高质量回答的机会，也可能放大选择偏差；两种作用都必须在程序固定后重新评价。

¹⁴ G. Loaiza-Ganem, K. Zhang, W. Cui, M. T. Law, K. K. Leung, *Conf-Gen: Conformal Uncertainty Quantification for Generative Models* In Proceedings of the 43rd International Conference on Machine Learning, 2026, pp. 80383–80412

11.5 本章小结

章首的 0.9 必须对应明确事件，并通过数据检验其频率含义。不确定性小、准确率高和校准性好是不同性质，可靠性检验还需兼顾信息量。

结果波动与知识不足是不确定性的两类来源。后验近似与深度集成估计模型间的预测分歧，条件分布与分位数学习刻画给定模型中的结果波动；两者结合后形成预测分布或范围。它们提供了待检验的主张，而不是可靠性已经成立的证据。

可靠性检验从三个角度核查这些主张：校准、评分与覆盖检查数值含义，风险—处理比例曲线检查识别高风险预测的能力，局部条件下的复测检查总体结论是否掩盖重要群体。数值准确、筛选有效、结论在相关局部条件下仍有证据，这三方面相互补充，任何一个总体指标都不能代替其余判断。

预测范围覆盖与决策程序风险是两类不同的保证对象，其适用范围取决于概率量词、抽样条件和损失定义。共形方法把模型质量与边际有效性分开，却不能无条件实现逐输入覆盖；在线反馈可以维护长期比例，却允许短期失效。选择性训练只能改善候选程序，风险承诺仍需独立验证。生成任务还要区分措辞变化、语义分歧与事实错误。下一章将承接其中最关

键的条件变化：当输入和环境离开既有数据的范围，模型性能与这些可靠性承诺会怎样改变。

延伸阅读 Guo 等关于神经网络概率校准的研究适合继续比较分类准确率与概率质量；Angelopoulos 与 Bates 的共形预测综述则从有限样本覆盖出发，说明基础预测器、校准数据和集合效率各自承担什么职责¹⁵。。

若关注生成任务，可结合语义熵与共形风险控制的工作阅读。前者区分措辞变化和语义分歧，后者要求把开放输出转成明确风险对象；两条路线都不能把低不确定性直接解释为事实正确¹⁶。。

¹⁵ C. Guo, G. Pleiss, Y. Sun, K. Q. Weinberger, *On Calibration of Modern Neural Networks* In Proceedings of the 34th International Conference on Machine Learning, 2017, pp. 1321–1330; A. N. Angelopoulos, S. Bates, *A Gentle Introduction to Conformal Prediction and Distribution-Free Uncertainty Quantification* In arXiv preprint arXiv:2107.07511, 2022

¹⁶ L. Kuhn, Y. Gal, S. Farquhar, *Semantic Uncertainty: Linguistic Invariances for Uncertainty Estimation in Natural Language Generation* In International Conference on Learning Representations, 2023; G. Loaiza-Ganem, K. Zhang, W. Cui, M. T. Law, K. K. Leung, *Conf-Gen: Conformal Uncertainty Quantification for Generative Models* In Proceedings of the 43rd International Conference on Machine Learning, 2026, pp. 80383–80412

鲁棒性

邮件分类器在旧邮件上表现良好，换到新月份却频繁误拦。原因可能是图片压缩改变了识别特征，也可能是正常邮件开始使用过去常见于垃圾邮件的模板。前一种变化主要改变测量，后一种变化改变了特征与标签的关系。只有知道需要承受哪一种变化，才能判断模型是否鲁棒。

鲁棒性（robustness）描述模型在规定变化范围内保持有效表现的能力。它必须附带变化对象、范围和评价标准。评估一种变化后，既要检查预测性能损失了多少，也要区分能否证明局部稳定、能否识别已经超出适用范围的输入。改进方法则应针对诊断出的薄弱环节：改变训练约束、利用新环境信息，或限制缺乏证据的自动处理。分布变化下的可学习性条件见第 9 章；这里重点考察这些条件如何影响模型的检验与改进。

在第 10 章的三层架构中，鲁棒性主要属于系统属性或规范要求层：系统需要明确应当承受哪些变化，以及变化后至少保持怎样的任务表现。

上一章的可靠性承诺依赖数据与未来输入之间的联系。本章用变化条件下的风险测试、局部认证和拒绝效果检验这项联系改变后还剩下哪些证据，这些方法对应证据能力层。数据来源或部署中的模型状态继续变化时，原结论还要附带监测、失效触发、回退和复验条件，因而与威胁与生命周期治理层相连。

最不利扰动既可以用于描述测量误差，也可以由攻击者主动寻找；本章围绕变化范围与模型性能讨论共同基础，第 17 章再加入攻击权限、资源和损害路径。这样的区分使局部稳定性方法能够共用，却不把全部安全问题缩减为输入扰动。

12.1 模型的鲁棒性

变化本身不是脆弱性：图像压缩后仍能正确分类，就没有在该变化下暴露失效。本节分别确定“要求模型承受什么变化”和“模型为何未能承受变化”。前者给出评价范围，后者解释性能下降的机制；同一种变化可以暴露不同机制，同一种捷径也可能被多种变化触发。

12.1.1 变化范围与性能要求

设输入 $\mathbf{x}$ 的允许变化构成集合 $U(\mathbf{x})$ 。如果这些变化保留标签 y ，可以用最不利变化下的损失评价模型：

$$R_{\text{pert}}(f) = \mathbb{E}_{(\mathbf{x}, y) \sim \mathcal{P}} \left[\sup_{\mathbf{x}' \in U(\mathbf{x})} \ell(f(\mathbf{x}'), y) \right]. \quad (12.1)$$

集合 $U(\mathbf{x})$ 可以描述像素扰动、文本中的等义修改或测量误差，但它的合理性需要由任务确定。删除一句否定词可能只改变很少字符，却改变正确标签；此时要求输出不变本身就是错误的鲁棒性目标。

局部扰动并未涵盖全部分布变化。输入比例改变、标签比例改变和条件标签规律改变具有不同的信息要求，具体分类见第9.1.2节。对于回归或分类器 f ，环境 e 中的风险记为 $R_e(f)$ 。鲁棒性可以要求所有允许环境的风险均不超过容限，也可以要求相对于原环境的下降不超过给定幅度。绝对风险和下降幅度需要一起看：一个始终表现很差的模型，也可能几乎没有下降。

示例 12.1 总体表现掩盖群体脆弱性 在构造的旧环境中，99% 的邮件属于常见模板，其错误率为 1%；其余 1% 属于少见模板，错误率为 50%。总体错误率为 $0.99 \times 0.01 + 0.01 \times 0.5 = 1.49\%$ 。若新环境中少见模板的比例增至 30%，而各组内部错误率不变，总体错误率就变为 15.7%。失效并不要求模型参数或组内标签规律发生变化。

图 12.1 区分两类证据：找到一个允许范围内的错误输入，就能否定相应鲁棒性主张；确认整个邻域都稳定，则需要覆盖该范围的认证依据。后面的检验方法会分别处理这两个问题。

12.1.2 失效机制与信息缺口

给出变化范围后，还不能断定模型会失败。局部扰动可能跨越距离输入很近的决策边界；群体比例变化可能放大原来就存在的高错误率；特征与标签关系变化则可能使旧规则失效。上一小节的模板比例示例属于第二种：变化没有制造新的组内错误，却增加了困难样本的权重。这些情形应与错误标注、测量异常等训练数据问题分开调查，因为它们所需的补救信息不同。

模型优化训练损失时，并不会自动区分稳定依据与偶然相关。若训练集中的垃圾邮件常含某个页脚，模型可能依赖页脚而非内容；当正常邮件也采用该页脚时，这条捷径就失效。**捷径学习** (shortcut learning) 指模型借助在训练条件下有效、却不能支持预期迁移的规则完成任务。Geirhos 等以此联系背景、纹理等依赖，强调应同时考察数据与评价条件¹。

¹ R. Geirhos, J.-H. Jacobsen, C. Michaelis, R. Zemel, W. Brendel, M. Bethge, F. A. Wichmann, *Shortcut Learning in Deep Neural Networks In Nature Machine Intelligence*, 2020




图 12.1 允许变化、认证范围与攻击反例的集合关系示意。虚线圈表示 $U(\mathbf{x})$ ，内圈表示已有认证支持的稳定范围，方点 $\mathbf{x}'$ 是跨越决策边界的允许变化。圆的尺寸不是随机平滑的实验结果；搜索没有找到反例时，也不能直接把整个允许集合视为已认证。

捷径不能简单等同于容易提取的特征。页脚在某些固定业务中可能确实是有效依据，问题在于使用要求是否包含页脚改变而邮件性质不变的情形。也不能把高维特征全部视为捷径、把人工可读特征全部视为稳定依据：人工规则同样可能依赖过时的相关关系。判断需要观察改变相关关系后的表现，而不是仅凭特征的外观。

一个有用的诊断是构造内容与模板不一致的样本。假设训练集中 90% 的垃圾邮件使用模板甲，90% 的正常邮件使用模板乙。只读模板便能取得 90% 的准确率；如果按原比例随机划分测试集，这条规则还会在测试中得到支持。将两类模板均衡配到两种邮件上后，模板规则的准确率降为 50%。这是人为构造的对照，不代表所有模型都会选择模板，却说明随机留出为何不能自动检验所需的不变性。

捷径是失效的一种机制，有限覆盖则解释为何训练证据可能没有排除它。增加训练环境的多样性可以暴露不稳定关系，但多样性也需要与目标变化相关。大量近重复样本未必增加有效覆盖。若目标环境的标签规律在现有数据中完全无法区分，复杂模型、正则化或无标签适应都不能凭空补上信息。定理 9.3 中的不可识别反例正是这种边界。

如果任务中的真实标签关系已经改变，继续保持原输出也不再是正确目标。例如同发件主体被接管后，系统需要根据新信息改变判断。此时应问能否及时发现并学到新规律，而不是要求对变化一律不敏感。鲁棒性要求保持的是任务表现，只有在标签保持的变化下，才能进一步把它表达成输出不变。

12.2 鲁棒性的检验

鲁棒性检验需要区分三类结论：规定变化发生后，任务风险有多大；在一个明确邻域内，能否排除所有预测翻转；对未覆盖的输入或变化，系统能否及时识别并限制损失。第一类依靠带标签测试，第二类需要认证条件，第三类检验监测与拒绝策略。三者相互补充：报警不代表模型必然失效，未报警也不构成稳定性证明。

12.2.1 变化条件下的风险检验

检验应从需要保持的性质出发。测量扰动测试在尽量保留任务含义的条件下改变噪声、分辨率或缺失比例；跨环境测试使用不同时间、来源或设备的数据；场景切片则检查可能被总体平均掩盖的输入。对每一种变化，都应报告强度、标签是否重新核验以及覆盖范围。

同一样本变化前后的配对比较可以减少样本组成差异，但不能替代真实新环境评价。人工构造的变化适合隔离因素，实际环境更能反映因素之间的耦合。若测试数据已经用于选择增强策略，还需要留出新的环境或扰动组合，检查是否只是适应了这组测试。

ImageNet-C 把常见图像损坏组织为噪声、模糊、天气和数字处理等类型，并设置不同强度；ImageNet-P 进一步考察连续小变化引起的预测不稳定。两者将“在变化下表现如何”变为可重复比较的问题，但所检验的是规定的损坏和扰动，不能据此声称对所有自然变化或最坏扰动都鲁棒²。

这类基准中的归一化指标也需要读懂。例如，以参考分类器在同种损坏上的累计错误率作为分母，再对不同损坏求平均，可以减少损坏类型本身难度的影响。但得到的是相对参考模型的表现，并不是部署错误率。若实际环境以压缩损坏为主，基准中对天气和噪声的等权平均就未必对应实际收益。报告应保留按类型、强度分解的曲线，并同时给出未损坏数据的表现。

真实环境变化还包括数据来源、时间和对象群体之间的差异。WILDS 汇集跨医院、相机位置、时间和地理区域等分布变化任务，并为各任务规定相应的划分和评价。它提醒读者：随机划分得到的域内结果，与按来源划分得到的域外结果，可以回答很不同的问题³。

² D. Hendrycks, T. Dietterich, *Benchmarking Neural Network Robustness to Common Corruptions and Perturbations* In International Conference on Learning Representations, 2019

³ P. W. Koh, S. Sagawa, H. Marklund, S. M. Xie, M. Zhang, A. Balsubramani, W. Hu, M. Yasunaga, R. L. Phillips, I. Gao, T. Lee, E. David, I. Stavness, W. Guo, B. Earnshaw, I. Haque, S. M. Beery, J. Leskovec, A. Kundaje, E. Pierson, S. Levine, C. Finn, P. Liang, *WILDS: A Benchmark of in-the-Wild Distribution Shifts* In Proceedings of the 38th International Conference on Machine Learning, 2021, pp. 5637–5664

变化还可能使不确定性表达先于准确率失效。Ovadia 等将多种不确定性方法放到分布变化下比较，同时观察准确性、概率评分和校准指标怎样随变化强度改变。这类评价能够区分“预测错误增加”和“模型仍以过高把握给出错误判断”，但结论仍限于所构造的变化条件⁴。

将邮件按月份留出也有类似作用，但要防止近重复邮件或同一会话跨越训练和测试。若目标是适应新机构，则应按机构而非逐封邮件划分；若目标是适应未来月份，则应保留时间顺序。划分单位要匹配未来未知的因素。跨环境检验还应记录调参能够访问哪些环境，因为使用目标环境标签挑出的模型，与完全未见目标环境的模型，不能直接当作同一设定下的方法比较。

报告平均风险时，还应报告与使用相关的群体风险、样本数和不确定性。样本较少的群体通常具有更宽的统计区间，不能因为点估计较低便断定可靠。示例 12.1 提示，变化环境中的总体风险还依赖组比例，因此应把组内表现与组比例变化分开。

对每个测试环境 e ，用未参与训练与调参的 n_e 个带标签样本估计

$$\begin{aligned}\hat{R}_e(f) &= \frac{1}{n_e} \sum_{i=1}^{n_e} \ell(f(\mathbf{x}_{e,i}), y_{e,i}), \\ \hat{\Delta}_e &= \hat{R}_e(f) - \hat{R}_0(f),\end{aligned}\tag{12.2}$$

其中 0 表示参考环境。报告绝对风险 $\hat{R}_e$ 与增加量 $\hat{\Delta}_e$ ，再按变化强度和关键群体展开，才能区分“原本就差”和“变化造成退化”。若预先约定风险容限为 ρ ，应把相应风险置信上界与 ρ 比较，而非仅看点估计是否低于它。对同一原样本生成多种扰动时，不能把相关的变体当成相互独立的样本计算区间；抽样与不确定性分析应保留原样本这一单位。

比较改进前后的模型时，应同时检验变化环境、原环境和关键群体中的表现。更新可能改善新模板却遗忘旧模板，也可能只改善检测到的变化而损害其他输入。评价数据与停止规则需要预先明确，否则持续观察并选择最好时刻同样会产生选择偏差。

没有足够证据支持更新时，保留原模型、缩小自动处理范围或回退都是控制损害的选择。它们不等于提高模型本身的鲁棒性，而是降低不确定更新的使用风险。模型能力与系统应对措施应分别报告。

部署评价可以保留冻结模型作为对照，按时间窗口比较原模型和适应模型的预测，并在标签返回后核算风险差异。若需要边运行边挑选更新时刻，置信结论必须考虑重复检验；若标签仅来自被转交人工的邮件，还要处理选择性观测，不能直接将该子集的错误率当作全量错误率。鲁棒性改进由此回到前章的证据问题：有效的变化目标、独立的检验和可解释的保证条件缺一不可。

⁴ Y. Ovadia, E. Fertig, J. Ren, Z. Nado, D. Sculley, S. Nowozin, J. V. Dillon, B. Lakshminarayanan, J. Snoek, *Can You Trust Your Model's Uncertainty? Evaluating Predictive Uncertainty Under Dataset Shift* In *Advances in Neural Information Processing Systems*, 2019

12.2.2 邻域内稳定性的认证

测试集上的风险估计仍只涉及已生成的样本。若要求“半径内每一个允许输入都不翻转”，则检验对象变成一个带全称量词的命题，不能靠增加几个随机变体来替代证明。

对式(12.1), 有限搜索只提供最坏损失的下界: 找到一次失败便能证实脆弱性, 没有找到却不能证明不存在。若能够证明函数的变化上界, 才可能获得认证。例如, 二分类实值分数 f 在 $U(\mathbf{x})$ 内满足 $|f(\mathbf{x}') - f(\mathbf{x})| \leq L\|\mathbf{x}' - \mathbf{x}\|_2$, 若以 $\mathbf{x}$ 为中心的半径 r 球包含于 $U(\mathbf{x})$, 且 $f(\mathbf{x}) > Lr$, 则球内分数保持为正。这只认证相应范数范围内的符号不变; 若原预测就错了, 认证不变也不会让它正确。

图 12.2 把这一证明条件放到二维输入平面。认证球内的每一点都受同一个变化上界保护; 球外同时存在预测不变的点与反例, 因而没有证书不能被解释为已经失败。




图 12.2 Lipschitz 条件支持的认证区域。构造 $f(\mathbf{x}) = x_1 + 0.2x_2$, 中心为 $(0.8, 0)$, 可取 $L = \sqrt{1.04}$ 。半径 $r = 0.7$ 满足 $0.8 > Lr$, 所以闭球内分数始终为正。深色直线是零分数边界, 认证球外的空心点仍为正, 叉号则为负; 球外不属于此证书的结论范围。认证保持的是预测符号, 不保证原预测标签正确。

局部认证也可以针对一个经过专门构造的预测规则进行。此时必须把认证对象写清, 不能将新规则的证书直接套给原模型。**随机平滑** (randomized smoothing) 让基础分类器 h 在输入加入随机噪声后投票, 以投票概率最大的类别作为新分类器的输出:

$$g(\mathbf{x}) = \arg \max_k \mathbb{P}_{\boldsymbol{\varepsilon} \sim \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I})} \{h(\mathbf{x} + \boldsymbol{\varepsilon}) = k\}. \quad (12.3)$$

这里 $\mathbf{x} \in \mathbb{R}^d$, $\mathbf{I}$ 为 d 阶单位矩阵, $\sigma > 0$ 是噪声标准差。Cohen 等建立了

高斯平滑对应的 ℓ_2 认证半径，关键在于平移高斯分布时，同一分类区域的概率不能任意快速改变⁵。

具体地，若类别 a 的投票概率至少为 $\underline{p}_a$ ，每个其他类别的概率至多为 $\bar{p}_b$ ，且 $\underline{p}_a > \bar{p}_b$ ，那么在

$$\|\delta\|_2 < r_{\text{cert}}, \quad r_{\text{cert}} = \frac{\sigma}{2} \left[\Phi^{-1}(\underline{p}_a) - \Phi^{-1}(\bar{p}_b) \right] \quad (12.4)$$

内，平滑分类器满足 $g(\mathbf{x} + \delta) = a$ 。 Φ 为标准正态分布函数。认证对象是 g ，不是任意一次加噪得到的 h 的输出，也不是未经平滑的原模型。

实际投票概率要用蒙特卡洛采样估计，因此应使用具有规定置信度的概率界。若二分类中获得 $\underline{p}_a = 0.9$ ，可取 $\bar{p}_b = 0.1$ ；令 $\sigma = 0.25$ ，认证半径约为 $0.25 \times 1.282 = 0.3205$ 。这些数字是假设的概率界，不能把观察到 90% 投票比例直接代入充当界。选类别与估计概率可以使用独立采样，界不足以分离类别时则拒绝认证。

增大 σ 不一定扩大实际认证半径，因为噪声更强也可能使投票概率接近，甚至损害正确率。平滑还需要多次前向计算。检验时应报告随半径变化的认证准确率，即既预测正确、又能认证该半径的样本比例，并报告采样成本与失败概率。这里的概率来自认证程序对投票概率的估计；上一章的覆盖保证涉及新样本和校准数据，二者的随机对象与量词不同。

给定需要承受的开球半径 r ，实际检验应逐个样本计算预测是否正确、认证半径是否至少为 r ，再统计两项同时成立的比例。改变 r 得到认证准确率曲线，并列报告对同一预测规则进行经验搜索所得的鲁棒准确率。搜索成功找到的错误给出反例，证书成功给出该样本邻域内的保证；搜索未成功且认证也未成功的样本，则仍处于未判定状态。单点认证不自动说明测试样本代表了未来环境，关于总体风险的推断仍需前章的抽样条件。

12.2.3 变化识别与拒绝效果的检验

对于超出已检验范围的输入，系统还可以报警或转交人工。这不能证明分类器在变化后保持正确，却能检验系统是否识别出了需要限制使用的条件。评价时应同时关注“有没有识别到变化”和“这种识别是否减少了实际损失”。

分布外检测 (out-of-distribution detection) 试图识别与参考数据不同的输入。可以利用表示空间距离、密度相关评分或模型输出构造检测分数，再在验证数据上选择阈值。但低密度不等于难以预测，高置信度也不能排除陌生输入。检测器应依据漏检与误报成本评价，而不只报告排序指标。

给定一个固定的异常分数，检验应另留正常输入与规定的未知类别或来源，并在独立验证数据上选定阈值。测试时计算正常输入被误拒的比例，

⁵ J. Cohen, E. Rosenfeld, Z. Kolter, *Certified Adversarial Robustness via Randomized Smoothing* In Proceedings of the 36th International Conference on Machine Learning, 2019, pp. 1310–1320

以及未知输入被误接纳的比例；改变阈值可以得到检测曲线，选定阈值后则应报告两种错误及其成本。接收者操作特征曲线下面积检验的是分数排序，不直接表示部署成本。文献中的 FPR95 有时把域内样本定义为正类，表示保留 95% 域内样本时误接纳域外样本的比例，必须核对正类与分母。

未知输入也可能被正确分类，熟悉输入也可能预测错误，因此还需取得真实任务标签，在被接纳的样本上计算风险，在全体样本上计算自动处理比例，并计入转交或拒绝的成本。比较两个检测器时，应固定处理比例或成本口径。这把检测评价接回第 11 章的选择性风险检验：分布外标签用来检查陌生程度识别，任务标签用来检查是否真正减少错误，两种证据不能互换。具体检测分数与训练方法将在第 12.3.3 节展开。

漂移检测 (drift detection) 则考察一段数据流是否发生统计变化。输入变化未必导致错误率上升，而输入统计稳定也可能伴随标签关系变化。没有及时标签时，漂移信号只能触发调查或更保守的策略；它不能直接说明该采用哪一种新模型。

例如，新月份的邮件模板比例改变，可能触发特征分布检验；但若模型本来就不依赖模板，预测风险未必增加。相反，原来合法的发件主体被接管后，相似输入可能对应新的风险标签，输入边缘分布检验不一定及时发现。监测中应保留少量持续获取真实标签的渠道，将输入信号与错误率、行动损失对应起来。第 11 章的统计区间适用于明确抽样条件下的风险检验，不能直接套到任意反复查看和筛选后的数据上。

检验漂移报警时，可以将保留时间顺序的数据流分成明确的无变化段与变化段。在无变化段统计误报频率，在已知变化开始时刻的测试中统计漏报比例与报警延迟，并报告窗口大小、阈值和重置规则。若真实变化时刻未知，则只能报告可核实的统计差异和后续风险，不应把每次报警都当作真阳性。获得延迟标签后，还需对照报警前后的任务风险；若报警触发了拒绝或更新，则单独核算该措施的收益和代价。

12.3 鲁棒性的增强

检验暴露薄弱环节后，改进措施应与薄弱环节对应。标签保持扰动引起的错误，需要约束局部行为；困难群体或环境捷径，需要改变训练时看重的风险与依据；已经超出已知范围的输入，需要有依据的拒绝策略；新环境中可获得的信息，则可能支持部署后适应。这些措施作用于不同对象，可以组合使用。前三者不要求持续更新部署参数，适应方法则改变运行中的模型状态，因此还承担错误积累与遗忘的风险。

选择这些约束前，还需辨别失效是否源于训练数据污染。对异常数值或标签噪声，稳健损失和重加权可以限制单个样本的影响。例如，Huber 损失在小残差处保留平方惩罚，在大残差处改为线性增长，从而避免极端残

差主导拟合。但真实少数群体也可能产生较大残差，机械降低其权重会使它们更难被学到。因此需要区分数据错误与模型尚未覆盖的合法样本。

12.3.1 输入变化下的行为约束

数据增强把预期变化转化为训练样本。对于保留标签的变换 T ，可以最小化 $\ell(f(T(\mathbf{x})), y)$ ；若只有无标签样本，也可以约束变换前后输出接近。前提是变换与任务相容，过强的一致性要求可能抹掉本来有意义的差别。

当变换难以逐项列举时，可以约束样本之间的行为。**混合增强** (mixup) 将两个样本及其标签按相同比例插值，鼓励模型在训练样本之间平缓变化。若 $\mathbf{e}_y$ 为类别 y 的独热标签，构造

$$\begin{aligned}\tilde{\mathbf{x}} &= \lambda \mathbf{x}_i + (1 - \lambda) \mathbf{x}_j, \\ \tilde{\mathbf{y}} &= \lambda \mathbf{e}_{y_i} + (1 - \lambda) \mathbf{e}_{y_j},\end{aligned}\tag{12.5}$$

其中 λ 通常从对称 Beta 分布抽样。用软标签交叉熵训练，相当于按 λ 和 $1 - \lambda$ 分担两个类别的损失，而非给插值点强行指定某一端的标签⁶。

例如， $\lambda = 0.7$ 时，若模型对两端类别给出 (0.7, 0.3)，就符合该训练目标希望表达的混合关系。它增加了样本之间的函数形状约束，但线性插值未必具有真实语义：把两封离散文本按字节混合通常没有意义，在表示空间插值也需要另行验证。即便原样本标签都正确，插值标签仍然是一项建模假设。混合增强因而不是式 (12.1) 中标签保持邻域的直接枚举。

对于图像中的常见损坏，AugMix 采用另一条路线：对同一图像执行若干随机增强链，将结果混合，并保留与原图的混合通路；训练时还可约束原图和多个增强视图的预测一致。其主要目标是让模型在多种合理变化及其组合下保持稳定，而不是在两种类别之间指定线性过渡⁷。

两种增强的区别落在约束对象上：mixup 约束样本之间的插值行为，AugMix 约束同一样本多个视图之间的行为。若把增强效果只概括为“增加数据量”，就会忽略这些假设。训练前应检查变换是否破坏小目标、颜色语义或文字方向；训练后还应在未使用的损坏类型和组合上复查，避免把对某套增强算子的熟悉当作一般鲁棒性。

在标签保持的邻域内，仅随机抽样增强可能漏掉损失较高的位置。直接优化最不利邻域损失，可以迫使模型关注这些位置，但也可能改变原数据上的决策边界。TRADES 把分类错误与边界附近的不稳定联系起来，并据此构造兼顾自然准确率与局部稳定性的代理目标⁸。

⁶ H. Zhang, M. Cisse, Y. N. Dauphin, D. Lopez-Paz, *mixup: Beyond Empirical Risk Minimization* In International Conference on Learning Representations, 2018

⁷ D. Hendrycks, N. Mu, E. D. Cubuk, B. Zoph, J. Gilmer, B. Lakshminarayanan, *AugMix: A Simple Data Processing Method to Improve Robustness and Uncertainty* In International Conference on Learning Representations, 2020

⁸ H. Zhang, Y. Yu, J. Jiao, E. P. Xing, L. El Ghaoui, M. I. Jordan, *Theoretically Principled Trade-off between Robustness and Accuracy* In Proceedings of the 36th International Conference on Machine Learning, 2019, pp. 7472–7482

以多分类概率模型 $p_{\theta}(\mathbf{x})$ 为例，一种常用形式为

$$\min_{\theta} \mathbb{E}_{(\mathbf{x}, y)} \left[-\log p_{\theta, y}(\mathbf{x}) + \beta \sup_{\mathbf{x}' \in U(\mathbf{x})} D_{\text{KL}}(p_{\theta}(\mathbf{x}) \parallel p_{\theta}(\mathbf{x}')) \right], \quad (12.6)$$

其中 $\beta > 0$ 控制对稳定性的重视程度， D_{KL} 为两个类别分布的 KL 散度。第一项要求原输入预测正确，第二项寻找使预测分布偏离最大的允许变化，再惩罚这种偏离。若去掉第一项，恒定输出也能使稳定性项为零，却无法完成分类。

该目标也解释了为何不能不加区分地扩大邻域。若两个标签不同的样本邻域重叠，要求两个邻域内都保持各自标签，会产生冲突。应先核对扰动范围的任务含义，再选择权衡系数。内层搜索还需要额外计算，并通常只能近似求解；优化了这项目标不等于获得形式认证。具体如何搜索攻击样本以及检验防御是否只是遮蔽梯度，留到第 17 章讨论。

图 12.3 把式 (12.6) 的两层优化分开：内层固定参数搜索更不稳定的允许输入，外层再用原输入损失与分布偏离更新参数。内层只找到搜索过程中的候选，不能把该候选写成已经证明的全局最坏输入。




图 12.3 TRADES 中的内层搜索与外层更新。内层在 $U(\mathbf{x})$ 中近似增大原输入与扰动输入预测分布的 KL 散度，外层最小化原输入分类损失与加权 KL 项，再用更新后的参数重新搜索。箭头示意搜索轨迹，概率条只示意分布发生偏离，不来自实验。该训练流程不提供全邻域的形式证书。

图 12.4 用有限的教学候选说明两项准确率可能怎样变化。沿 A、B、C 选择时存在取舍，候选 D 却同时改善了 B 的两项表现，因此这张图不能被理解为所有任务都存在同一条不可越过的准确率边界。




图 12.4 原输入准确率与鲁棒准确率的一种可能取舍。固定 100 个构造样本及同一标签保持扰动范围，A、B、C 的两项正确数分别为 80/70、88/60、94/45；D 为 90/74，同时优于 B。每个候选的鲁棒正确样本都是原输入正确样本的子集。虚线只连接三个教学候选，不是实测曲线或普遍最优边界；评价仍需固定扰动定义与搜索条件。

以上方法改变的是模型及其训练约束，实际收益仍应回到第 12.2.1 节的独立变化测试。需要严格邻域结论时，另按第 12.2.2 节执行认证；训练目标变小与认证半径变大不是同一件事。

12.3.2 跨环境风险与稳定依据的约束

局部增强规定同一样本附近的行为，却未必解决困难群体被平均损失忽视、或不同环境中预测依据失效的问题。这里保持任务损失的含义，改变模型对哪些环境负责，以及跨环境允许依赖哪些关系。

若预期一组环境或分布都可能出现，可以用**分布鲁棒优化**（distributionally robust optimization, DRO）直接优化最不利分布：

$$\min_f \sup_{Q \in \mathcal{Q}} \mathbb{E}_Q \ell(f(\mathbf{x}), y). \quad (12.7)$$

这里 $\mathcal{Q}$ 是允许分布组成的集合。集合过小会漏掉实际变化，过大则可能要求模型抵抗没有任务意义的情形。距离、半径和分组方式都应对应具体使用条件。

若允许分布只是若干组分布的任意混合，式 (12.7) 化为最小化最大组风险。它能防止大群体在平均目标中压过小群体，但经验最坏组风险很小仍不保证新样本上的组风险小。Sagawa 等的研究强调，过参数化模型可以同时拟合各组训练数据，最坏组泛化仍需要正则化与验证⁹。

⁹ S. Sagawa, P. W. Koh, T. B. Hashimoto, P. Liang, *Distributionally Robust Neural Networks for Group Shifts: On the Importance of Regularization for Worst-Case Generalization* In International Conference on Learning Representations, 2020

这个化简可以直接看出。设第 g 组的分布为 $\mathcal{P}_g$ ，组比例 $q_g \geq 0$ 且 $\sum_g q_g = 1$ ，则混合分布风险为 $\sum_g q_g R_g(f)$ 。允许任意组比例时，最不利比例会把全部权重放到风险最大的一组，因此

$$\sup_{\mathbf{q} \in \Delta_G} \sum_{g=1}^G q_g R_g(f) = \max_{1 \leq g \leq G} R_g(f), \quad (12.8)$$

其中 $\Delta_G = \{\mathbf{q} \in \mathbb{R}^G : q_g \geq 0, \sum_g q_g = 1\}$ 是 $\mathbb{R}^G$ 中具有 G 个概率分量、仿射维数为 $G-1$ 的概率单纯形。示例 12.1 中，普通平均目标受 99% 常见模板支配，最坏组目标却会把 50% 的少见模板错误率当作需要优先改善的部分。

计算时可以交替更新模型和组权重：高损失组增加权重，模型随后更重视这些组。若只允许组比例在当前比例附近变化，也可以缩小权重集合，减轻对极端混合的保守性。不过，分组太粗会掩盖组内捷径，分组太细又会产生估计不稳定的小组。组标签本身也可能不可得；仅按高损失自动分组，可能把标注错误与合法困难群体混在一起。此时需要数据诊断，不能认为优化目标会自动辨认二者。

最坏组风险与公平差异也不能互换。把所有组的损失都降到较低水平，仍可能留下机会分配或行动成本上的不合理差异；反过来，两组错误率相同，也可能意味着两组都表现很差。第 13 章将先确定需要保护的分配原则，再决定哪些组间比较有意义。本节的组 DRO 只针对已经给定的损失与组分布提供优化目标。

跨环境稳定关系学习进一步寻找多个环境中共同有效的依据。这个方向依赖训练环境足以打破不稳定相关。关于不变性要求何时能够支持目标域保证，可回到第 9.3 节；单独观察训练环境上的一致性不足以证明任意新环境有效。

不变风险最小化所寻求的是：在学习到的表示上，同一个预测规则能够同时适用于多个训练环境。它与组 DRO 的关注点不同；组 DRO 限制最坏组损失，不要求各环境的最优预测规则相同。若所有训练环境中模板与标签都同向相关，不变性目标仍可能接受模板捷径；若不同环境对目标的定义本来就不同，强求同一规则还可能删除有用信息。

方法比较因而必须包含认真调优的经验风险最小化基线。DomainBed 在统一的训练和模型选择条件下比较多种域泛化方法，发现不少方法未能稳定超过强 ERM 基线，说明算法名称不能代替公平的训练与验证流程¹⁰。

。

这里并不能推出 ERM 在所有变化下最优。它说明，在声称某种鲁棒目标有效以前，应固定架构、训练预算、数据增强和可用验证环境，检查收益究竟来自目标函数还是其他选择。第 9 章给出的条件解释可识别性，本

¹⁰ I. Gulrajani, D. Lopez-Paz, *In Search of Lost Domain Generalization* In International Conference on Learning Representations, 2021

节的受控比较则检查具体算法是否把可用信息转化成实际收益。

12.3.3 超出适用范围时的拒绝策略

当已有训练信息不足以支持所有输入时，可以为预测规则增加接纳条件。拒绝策略的目标是缩小缺乏证据的自动处理范围；它增强系统对变化的应对能力，并不让被拒绝输入上的原分类器自动变得正确。其代价是处理比例下降或人工负担增加，应与模型性能改善分别报告。

一个无需另训模型的基线是**最大类别概率**（maximum softmax probability, MSP）：用最大的预测概率作为熟悉程度分数，过低时拒绝分类。Hendrycks 与 Gimpel 将它作为错误样本和分布外样本检测的基本比较对象¹¹。。

这个分数只比较给定类别之间的相对支持。假设两个输入类别得分分别是 (10, 9) 和 (1, 0)，经过 softmax 后得到相同的最大概率，约为 0.731。类别间差距相同，并不意味着两个输入都得到同样强的整体支持。这个构造也说明，上一章对类别概率作校准，不能单独解决未知类别的识别：检测需要另行规定未知的含义与测试分布。

为保留归一化前打分的信息，可以使用**能量分数**（energy score）。设分类器有 K 个类别，对类别 k 的实值打分为 $z_k(\mathbf{x})$ ，温度 $T > 0$ ，定义

$$E_T(\mathbf{x}) = -T \log \sum_{k=1}^K \exp\left(\frac{z_k(\mathbf{x})}{T}\right). \quad (12.9)$$

通常将较高能量作为分布外信号。Liu 等研究了直接用该分数检测，以及训练时拉开域内、域外能量间隔的方案¹²。。

对上面的两个打分向量，取 $T = 1$ ，能量分别约为 -10.313 与 -1.313，因而能够将它们区分。但“能够区分”不等于“区分正确”。给全部类别打分增加同一个依赖输入的常数，不改变分类概率，却改变能量；纯分类目标本身并不能唯一确定输入密度。能量阈值仍须在实际模型和验证数据上检查，不能把未经生成式拟合的能量直接宣称为真实数据的负对数密度。

如果能够取得一批辅助异常数据，还可以主动教模型区分已知任务与任务外输入。**异常暴露**（outlier exposure, OE）在正常分类损失外，加入对辅助异常样本的约束；分类任务中的一种实现要求这些样本的预测接近均匀分布，从而避免对它们随意给出尖锐类别判断¹³。。

辅助异常数据不是最终未知世界的完整代表。若训练和测试使用相同来源的异常样本，检测器可能学会来源线索而非可迁移的拒绝规则。因此应另留未参与训练的异常类别和来源，并报告相近未知类别与明显不同输入上的差异。其拒绝效果需按第 12.2.3 节的独立数据和固定阈值检验。

¹¹ D. Hendrycks, K. Gimpel, *A Baseline for Detecting Misclassified and Out-of-Distribution Examples in Neural Networks* In International Conference on Learning Representations, 2017

¹² W. Liu, X. Wang, J. D. Owens, Y. Li, *Energy-based Out-of-distribution Detection* In arXiv preprint arXiv:2010.03759, 2020

¹³ D. Hendrycks, M. Mazeika, T. Dietterich, *Deep Anomaly Detection with Outlier Exposure* In International Conference on Learning Representations, 2019

12.3.4 利用新环境信息时的风险与验收

当新环境数据可以获得时，系统可以重新估计统计量、更新部分参数，或利用模型产生的标签调整预测规则。这类**测试时适应**（test-time adaptation）改变了部署中的模型状态，具体算法与训练过程留待第四卷“范式”的“知识的演进与迁移”部分讨论；这里关注更新会怎样改变可信主张，以及需要什么证据才能继续使用模型。

没有真实标签时，适应通常依赖预测置信度、一致性或其他代理信号。代理目标改善不等于任务风险下降：错误预测可能被进一步强化，始终输出同一类别也可能得到看似稳定的无监督指标。限制更新参数、步长或样本范围可以缩小影响，却不能提供正确方向。若能取得少量真实标签，应优先用它们核验更新后的任务表现，而不是只报告代理目标。

数据流的组织也属于被验收的程序。批次大小、样本顺序、每次预测发生在更新前还是更新后、何时重置状态，都会改变后续输入所面对的模式。把测试数据随机打乱后离线更新，不能代表具有时间相关性的真实服务；只评价参与更新的高置信样本，又会遗漏被排除样本和困难群体上的风险。

适应程序应与冻结模型在同一时间顺序、输入流和资源预算下比较。验收至少同时报告原环境与新环境风险、变化轨迹、关键群体表现、更新失败后的回退效果，以及更新和保存状态的成本。模型在前一段时间的平均表现提高，不能掩盖某个短窗口中的严重退化；新环境改善也不能由旧能力遗忘来换取而不作说明。

若当前标签不足以判断更新方向，保持参考模型、缩小自动处理范围或回退，可能比继续优化代理目标更稳妥。这些措施控制的是不确定更新造成的损害，并不表示模型已经适应新环境。只有在模型、更新规则、状态与验收条件共同固定后，才能把评价结果归于这套适应程序。

12.4 前沿研究

基础模型覆盖较广，并不意味着每种变化都已经被预训练吸收。多个模态、任务或设备的变化可能同时出现，使单因素测试难以预测组合表现。一个研究重点是明确哪些表示能够迁移，以及增强某种不变性是否损害另一种任务需要的敏感性。

NeuroAdapt-Bench 在脑电基础模型上比较真实分布变化下的测试时适应。所评估方法的收益并不一致，部分更新造成性能下降，这为“无标签目标越低，预测越好”的假设提供了具体反例。结论限于论文中的模型、任务和适应方法，不能推广为所有测试时适应都无效¹⁴。

该工作把评价范围扩展到不同设备、人群与较大的模态变化，所测试

¹⁴ G. J. Lee, J. Pradeepkumar, J. Sun, *Test-Time Adaptation for EEG Foundation Models: A Systematic Study under Real-World Distribution Shifts* In Proceedings of the 11th Machine Learning for Healthcare Conference, 2026, pp. 948–984

的梯度更新方法尤其容易出现严重退化，免优化方法则表现得更稳定。它与早期图像损坏实验之间的联系，在于重新检查适应信号是否保留任务含义：图像中的增强一致性或类别聚集假设，不能未经检验直接移到脑电信号。基础模型的规模与覆盖改变了起点，却没有取消方法的适用条件。

持续适应还需要解决何时更新、何时重置和如何分配有限标签的问题。其困难与第 11 章相连：系统不仅要改善平均性能，还需要知道当前更新是否值得信任。长期平均改善可能掩盖短时间严重退化，评价应同时报告变化轨迹与最不利阶段。

12.5 本章小结

鲁棒性要求模型在规定变化下保持任务表现。局部扰动、群体比例变化和标签规律变化描述评价条件；邻域边界、原有群体误差和捷径依赖则解释这些条件怎样暴露脆弱性。两层问题分开，才能选择有意义的测试与补救措施。常见损坏基准隔离变化因素，跨环境划分考察现实迁移，检测与拒绝评价检查系统能否识别陌生输入并减少行动损失，局部认证则在明确邻域中排除预测翻转。这些证据各有范围，不能由一种测试成绩替代全部判断。

训练阶段增强与部署后适应共同回答如何提高变化条件下的有效性，但它们利用的信息和承担的风险不同。增强约束哪些输入应当具有相近行为，最坏组优化避免平均目标掩盖困难群体，局部稳定性训练处理邻域中的边界，而持续适应尝试利用新环境信息。它们都需要与认真调优的基线比较，并检查原环境、变化环境和关键群体中的得失。对于证据不足的更新，应同时考虑限制使用与回退。

开篇邮件分类器的误拦，至此可以先确定测量、群体比例或标签关系发生了什么变化，再调查邻域不稳定、既有群体误差或模板捷径如何导致损失，而无需把所有问题都归因于“数据变了”。当这些变化使错误集中在特定人群时，还需要判断不同人承担的损失是否合理。下一章将讨论公平性：在既定分配原则下，怎样比较机会、错误与负担，并改变造成不合理差异的环节。至于模型具体依赖了哪些因素，第 15 章将进一步提供解释与核验的方法。

延伸阅读 Hendrycks 与 Dietterich 关于常见损坏的基准、Koh 等人的 WILDS 任务集，适合对照受控扰动与真实来源变化怎样形成不同评价证据。阅读时应保留变化类型、数据划分和模型选择条件，避免把某个基准上的平均结果推广到所有环境¹⁵。

若希望继续研究改进方法，可从 TRADES 与组 DRO 比较局部稳定性和最坏组风险的不同目标；测试时适应的具体算法、状态更新和实践选择留

¹⁵ D. Hendrycks, T. Dietterich, *Benchmarking Neural Network Robustness to Common Corruptions and Perturbations* In International Conference on Learning Representations, 2019; P. W. Koh, S. Sagawa, H. Marklund, S. M. Xie, M. Zhang, A. Balsubramani, W. Hu, M. Yasunaga, R. L. Phillips, I. Gao, T. Lee, E. David, I. Stavness, W. Guo, B. Earnshaw, I. Haque, S. M. Beery,

到第四卷“范式”的“知识的演进与迁移”部分展开¹⁶。。

¹⁶ H. Zhang, Y. Yu, J. Jiao, E. P. Xing, L. El Ghaoui, M. I. Jordan, *Theoretically Principled Trade-off between Robustness and Accuracy* In Proceedings of the 36th International Conference on Machine Learning, 2019, pp. 7472–7482; S. Sagawa, P. W. Koh, T. B. Hashimoto, P. Liang, *Distributionally Robust Neural Networks for Group Shifts: On the Importance of Regularization for Worst-Case Generalization* In International Conference on Learning Representations, 2020

公平性

一个培训名额分配模型在总体上预测准确，却可能把大量合格申请者集中拒绝在某个群体中。判断这种结果是否公平，既需要知道错误如何分布，也需要知道名额应按什么原则分配。即使所有群体的准确率相同，误拒与误收的比例、获得机会的数量和实际后果仍可能不同。

前两章讨论预测的可靠性与变化条件下的鲁棒性。这些分析能够揭示错误集中出现的条件，却还没有规定不同人之间怎样分配机会和负担。名额分配的公平性需要明确自己的判断原则，不能由预测准确或性能稳定直接推出。

在第 10 章的三层架构中，公平性主要属于系统属性或规范要求层：它规定哪些机会、错误和待遇需要比较，以及哪些影响路径不可接受。群体统计、个体比较、因果分析和内容评价属于证据能力层，用来判断具体保护要求是否得到支持。群体构成、标签生成过程或决策的长期后果发生变化时，原有公平结论可能失效，因而还要在威胁与生命周期治理层持续监测、触发复查并保留纠正途径。

本章要回答的是：分配系统应保护什么、怎样判断保护要求是否满足，以及怎样改变造成不合理差异的环节。对公平含义、不公平表现和形成原因的分析先确定比较对象，再将保护维度、准则和检验方法对应起来，最后据此定位数据、训练或决策流程中的干预位置。判定准则决定干预目标，形成机制决定措施选择；措施是否有价值，还要看实际效果和长期反馈，不能只看某个指标是否下降。

图 13.1 用报名材料的装饰差异代替地区标签，突出比较所需的条件。假定材料中的三个资格项目已经覆盖当前认可的全部分配依据，且没有名额抽签等允许的随机机制，那么仅因封面不同而稳定地产生不同待遇，就违反了这一情景的个体一致性要求。现实审计需要验证这些假定，不能只凭两份材料外观相近便得出结论。

13.1 模型的公平性




图 13.1 相同资格下的不同待遇。上下两行表示同一系统对两名申请者的处理；三个相同图标表示相同的认可资格，条纹与圆点仅是无关的封面装饰。一人获得培训机会，另一人被拒，提示需要调查的差别待遇。图示为构造情景。

13.1.1 公平性的含义

公平性（fairness）要求模型及其使用过程依据任务认可的原则，对不同个体和群体合理分配机会、收益、错误与负担。它既关心谁得到什么，也关心依据什么作出决定，以及受影响者能否获得恰当处理。公平不等于所有人的输出相同；关键是哪些差异有合理依据，哪些差异违背了事先说明的保护要求。

例如，培训名额可以按现有资格、培训后的预期收益或弥补机会不足的需要分配。这些原则可能产生不同名单，不能靠准确率选出唯一正确原则。公平要求包含规范性判断，即在当前任务中什么差异应被允许、什么差异应被纠正。统计方法可以检查已经明确的要求，却不能单独决定应采纳哪一种分配原则。

设 $\mathbf{x}$ 为可用特征， $\mathbf{a}$ 为需要关注的群体属性， $y \in \{0, 1\}$ 为任务标签， $\hat{y}$ 为二元决策。本章在名额分配例子中令 $y = 1$ 表示按既定标准合格， $\hat{y} = 1$ 表示获得机会。标签的这一含义必须在实际任务中核查：历史上是否被录取，不等于是否具备资格。邮件例子中的正决策是隔离，本章则是提供机会；同一个错误率在不同任务中可能对应不同后果，不能脱离标签含义判断越高或越低越好。

判断公平还需要限定系统边界。数据中不同群体的数量、模型输出的分数、实际录取决定、参加培训的成本和最终收益，是不同层面的对象。预测概率相同，可能因决策规则不同而产生不同机会；录取决定相同，也可能因费用或服务条件不同而产生不同实际收益。本章把模型放回使用过程

讨论，避免用某一个环节的均等代替对完整后果的判断。

13.1.2 不公平的表现

可以从具体的待遇与后果识别需要调查的问题。设两个群体各有 20 名按同一标准认定的合格申请者，其中一组 18 人获选，另一组只有 10 人获选。在这个教学例子中，若保护要求是合格者不因群体不同而失去机会，那么两组不同的误拒程度就是需要解释和纠正的现象。若只知道两组总体录取率不同，却不知道采用了什么资格标准，就还不能直接断定哪一方受到不合理处理。

另一种问题发生在个体之间。假设两名申请者在所有被认可的任务条件上相同，系统却只因与任务无关的地区标签而稳定地给予不同录取机会，那么即使两个地区的总体录取率相同，也没有消除这种差别待遇。相反，对不同资格者作出不同决定是否合理，需要回到资格标准本身，而不能仅按输出是否一致判断。

还需区分**分配性伤害**（allocative harm）与**表征性伤害**（representational harm）。前者体现在谁得到名额、服务或资金，后者体现在谁被刻板描述、忽视或贬低。培训推荐系统可能给予各组相同数量的推荐，却在没有事实依据时反复把某些人描述为不适合技术岗位；机会计数相同，并未覆盖这种表达带来的影响。另一个需要检查的现象是服务负担：某组即使最终获选比例相同，却需要更多证明、更长等待或更多申诉才能完成申请。

实际研究也展示了总体指标掩盖差异的情形。Buolamwini 和 Gebru 的 Gender Shades 按研究中的肤色与性别标注交叉分析商用图像性别分类器，发现不同交叉组的错误水平存在明显差异。这项工作说明为何需要拆分评价；其结论限定在研究样本、标注方式和当时系统上，不能把肤色当作种族的无误替代，也不能把图像性别标注等同于人的完整性别身份¹。

上述表现分别指向机会与负担、预测质量、个体待遇和社会表征。它们帮助确定要检查什么，还不能单独回答差异由哪个环节造成；同一种表现可能来自不同原因，因而需要不同干预。

13.1.3 不公平的形成原因

问题可能从任务目标开始。如果把历史录取结果直接当作“是否合格”的标签，模型就可能学习过去的筛选习惯，而非当前认可的资格。即使模型准确复现了标签，也未必符合新的公平要求。这类问题需要重新说明预测目标和决策用途，不能只增加训练样本。

数据采集与测量会改变模型看见的世界。只从线上报名者收集样本，可能遗漏不易使用线上渠道的人；不同语言版本的测验难度不同，可能把测量差异写成能力差异；标注者使用不一致标准，又可能造成分组标签误差。

¹ J. Buolamwini, T. Gebru, *Gender Shades: Intersectional Accuracy Disparities in Commercial Gender Classification* In Proceedings of the 1st Conference on Fairness, Accountability and Transparency, 2018, pp. 77–91

样本不足、测量不等价和标签偏差是三种不同问题，补数量只能直接缓解其中一部分。

学习过程也可能放大已有差异。若训练目标只最小化总体平均错误，小群体上的较大损失可能被多数样本的改善抵消。某些特征还会传递被删除属性的信息，例如地区与既有资源高度相关时，删除显式群体字段并未消除这种关联。是否允许利用某项信息，需要依据任务原则及其影响路径判断，不能把“看不到群体字段”当成公平证明。用于审计、用于训练约束与直接用于决策的群体信息，也应分别说明用途。

部署环节决定分数怎样变成实际待遇。统一阈值未必对应各组相同错误率，不同阈值也未必符合个体一致性要求；人工复核、收费方式与等待时间还会改变模型以外的负担。只调整预测器而保留有问题的服务流程，可能使差异继续存在。

决策还会改变未来数据。在名额分配中，只有获得培训者才有后续成绩，形成**选择性标签**（selective labels）：结果能否观测取决于既有决策。如果直接用这些成绩训练，模型可能持续缺少被拒者潜在表现的证据。机会分配还可能改变下一轮的能力和资源，从而形成反馈。纠正这些问题需要额外观测或可识别假设，不能仅在已有记录上更换一个公平指标。

形成原因用于定位干预环节，公平判定则用于判断哪些要求没有满足。例如，在其他输入不变时修改邮政编码，若预测随之改变，可以得到模型依赖该输入的线索，却还不能判断这种依赖是否合理；预测没有改变，也不排除其他代理变量传递相同信息。后文第15.3节将介绍更系统的行为解释方法。需要把机制线索与明确的保护要求、比较对象和证据结合起来。

13.2 公平性的判定

判定公平性要把三个层次连起来：判定维度说明关心哪一种待遇或后果，公平准则规定什么关系应当成立，检验方法则用数据或实验检查该关系。例如，关心合格者是否同样有机会，是判定的内容；要求各组真正例率相同，是具体准则；按群体统计合格者中的获选比例并估计差距，是检验方法。三者不能只用一个算法名称代替。

下面从机会与负担的分配、预测错误与分数含义、相似个体的处理、决策依据与影响路径、生成内容中的社会表征五个方面展开。前两个方面主要通过群体统计检验，第三个通过个体成对比较，第四个需要关于影响路径的证据，第五个需要内容评价与受控比较。每个方面都说明比较对象、准则、操作方法与局限。末尾再讨论如何综合这些证据形成结论；准则取舍和证据强度是所有方面共同面对的问题，不是另外两种公平维度。

13.2.1 机会与负担的分配

这一维度检查谁获得服务或资源、谁承担申请和使用成本。先明确目标人群及分配单位，再比较各组的获得比例、资源数量或负担分布。例如培训机会应以符合所声明申请范围的人群为分母，而不是只统计最终完成线上报名者，否则可能遗漏在申请入口就被排除的人。

若保护要求是“各群体总体获得名额的比例应当相同”，比较时不再以资格细分人群，于是检查各组所有申请者中的获选比例。这个要求可以用**人口统计均等**（demographic parity）表示：

$$\mathbb{P}(\hat{y} = 1 \mid a = u) = \mathbb{P}(\hat{y} = 1 \mid a = v).$$

它直接约束机会分配，却没有使用资格标签。若标签存在明显偏差，这种不依赖标签的特征可能有意义；若资格差异是任务需要考虑的信息，又需要解释为何仍要求比例相同。

机会比例还可能用差值或比值报告。例如两个群体录取率为 0.02 与 0.04 时，绝对差仅为两个百分点，前者却只有后者的一半。差值便于表达额外影响了多少人，比值强调相对机会，两者都不能省略基准比例。

实际检验时，应在同一任务和时间范围内记录组别、是否获得机会以及等待时间、费用等负担。录取率用组内获选人数除以组内人数，群体间可以比较差值或比值；负担则可比较平均值、分位数或超过已声明上限的比例。容许差异与上限应由任务要求确定。最终录取率相同而某组需要更多申诉时，机会与过程负担会给出不同结论。

这里对总体获选比例的比较没有直接说明差异的原因，也没有以真实资格为条件。要判断合格者是否受到不同程度的误拒，还需下一小节的标签与错误分析。对于某一大群体内部是否藏有集中伤害，则应先细化当前比较的人群。

交叉群体中的细化检验 只检查几个大群体仍可能遗漏集中出现的伤害。设两个二元属性将人群均匀划成四组，四组录取率依次为 0.9, 0.1, 0.1, 0.9。分别按任何一个属性统计，两组录取率都为 0.5，交叉组之间却相差 0.8。Kearns 等将这种粗粒度统计通过而结构化子群失败的现象称为公平性划分操纵，并研究对子群族同时审计和学习的方法²。

令 $\mathcal{g}$ 为预先约定或受复杂度限制的子群判别函数族， $g(\mathbf{x}, a) = 1$ 表示属于某一子群。要定义**子群公平**（subgroup fairness），还必须固定参考总体。用事件 C 表示当前比较所针对的人群：人口统计均等可取 C 为全部申请

² M. Kearns, S. Neel, A. Roth, Z. S. Wu, *Preventing Fairness Gerrymandering: Auditing and Learning for Subgroup Fairness* In Proceedings of the 35th International Conference on Machine Learning, 2018, pp. 2564–2572

者，假正例率比较则取 $C = \{y = 0\}$ ，并要求 $\mathbb{P}(C) > 0$ 。记

$$\begin{aligned} r_C &= \mathbb{P}(\hat{y} = 1 \mid C), \\ \alpha_C(g) &= \mathbb{P}(g = 1, C), \\ r_C(g) &= \mathbb{P}(\hat{y} = 1 \mid g = 1, C) \quad \text{当 } \alpha_C(g) > 0. \end{aligned}$$

其中 r_C 是参考总体的正决策率， $r_C(g)$ 是子群内的对应比例， $\alpha_C(g)$ 是该子群在总体中的概率质量。对子群 g 定义加权违规量

$$\begin{aligned} v_C(g) &= \begin{cases} \alpha_C(g) |r_C(g) - r_C|, & \alpha_C(g) > 0, \\ 0, & \alpha_C(g) = 0, \end{cases} \quad (13.1) \\ \sup_{g \in \mathcal{G}} v_C(g) &\leq \gamma, \quad \gamma \in [0, 1]. \end{aligned}$$

给定容差 γ 后，最后一个不等式才构成对整个子群族的要求。分段定义避免在零概率子群上调用没有定义的条件概率。概率质量权重避免把极小子群中高度不稳定的原始比例差直接当成同等规模的总体违规；它 also 意味着报告结果时仍应同时给出子群大小和未加权差异。

检验时，审计器在 $\mathcal{G}$ 中搜索加权违规量 $v_C(g)$ 最大的子群，再用独立数据核验找到的差异，而不是只搜索原始率差最大的子群。这里改变的是比较人群的粒度，所比较的仍是已经选定的机会比例或条件错误率。若参考总体、容差或子群族改变，得到的是另一个公平要求；若子群族不包含真正受损的人群，或搜索算法找不到违规，未发现差异也不能排除其他群体受损。

13.2.2 预测错误与分数含义

获得机会的比例相同，不代表错误由各组同样承担。这一维度检查模型在不同群体上是否具有可接受的错误水平，以及同一分数是否具有相同含义。需要在预测与决策记录之外取得可信的真实标签；如果历史标签已经偏离认可的资格标准，精确计算错误率也可能检验错对象。

若重点是避免合格者因群体不同而被不同程度地拒绝，可以要求**机会均等** (equal opportunity)，即各组真正例率相同。进一步要求真正例率和假正例率都相同，则得到**均等化赔率** (equalized odds)：

$$\mathbb{P}(\hat{y} = 1 \mid y = b, a = u) = \mathbb{P}(\hat{y} = 1 \mid y = b, a = v), \quad b \in \{0, 1\}. \quad (13.2)$$

这些标准把标签作为比较资格的依据，其适用性随标签含义而变化。Hardt 等讨论了这类群体判定及给定预测器的后处理，并指出只依据联合统计量进行判断的局限³。

³ M. Hardt, E. Price, N. Srebro, *Equality of Opportunity in Supervised Learning* In arXiv preprint arXiv:1610.02413, 2016

概率校准要求具有相同预测概率的样本呈现相应的事件频率（见第 11 章）。公平性还可以进一步要求预测分数在每组中具有相同解释。例如，对预测合格概率 $p(\mathbf{x})$ 要求组内校准： $\mathbb{E}[y | p(\mathbf{x}), a] = p(\mathbf{x})$ 。它要求同一分数在每组对应相同事件频率，却不直接要求获得机会的比例或错误率相同。

把不同群体获选者中的合格比例相同称为**正预测值均等** (predictive parity)。它询问已获得机会的人有多大比例合格，分母是获选人数；这与在合格者中比较获选率的机会均等不同，也不等同于逐分数的组内校准。

这些要求可以按条件独立关系理解。人口统计均等要求 $\hat{y}$ 与 a 独立，均等化赔率要求给定 y 后 $\hat{y}$ 与 a 独立。若要求同一决策结果在每组对应相同的标签比例，则考察给定 $\hat{y}$ 后 y 与 a 是否独立；其中对 $\hat{y} = 1$ 的要求，就是正预测值一致。条件放在不同位置，意味着保护对象不同：申请者关注同等资格能否获得机会，名额分配者可能关注被选者达到目标的概率。必须说明采用哪一个视角，以及为什么这一视角适合当前任务。

按标签与分数进行检验 若组内没有正例，真正例率没有定义；把这种情况记为零再计算差距，会把缺少证据误写成最差表现。其他条件概率同样需要检查分母，不能只保存最后一个差距数。

示例 13.1 同一批申请者上的不同公平指标 构造两个各 100 人的群体，其中合格者分别为 20 人和 60 人。第一组有 16 名合格者与 8 名不合格者获得机会，第二组对应为 48 名与 4 名。两组的获选比例为 $24/100 = 0.24$ 与 $52/100 = 0.52$ ；真正例率为 $16/20 = 0.8$ 与 $48/60 = 0.8$ ；假正例率为 $8/80 = 0.1$ 与 $4/40 = 0.1$ ；正预测值为 $16/24 \approx 0.667$ 与 $48/52 \approx 0.923$ 。

因此，在这批构造数据上，均等化赔率的两项差距均为零，人口统计均等的差距却为 0.28，正预测值差距约为 0.256。若把公平仅记为“两个群体相同”，就无法说明其中哪一个结论成立。这里给出的都是样本比例，推向未来申请者时仍需估计误差。

图 13.2 先对照这批记录中的三项准则：获选比例、按资格细分的获选率与已获选者的合格比例。共同的真正例率和假正例率并没有抹去两组原有合格比例的差异，因此另外两项比例仍然不同。这个例子说明准则不能互相替代；它们能够兼顾到什么程度，还要在第 13.2.7 节结合基准比例与错误率推导。

图 13.3 将同一批记录按资格与决策交叉排列。观察每项指标的分母，就能看出它保护的是全体申请者、合格者、不合格者，还是已经获选的人。

这个例子的混淆矩阵尚不能检验分数校准，因为它没有记录每个人的




图 13.2 同一批申请者上的三种公平准则。沿用示例 13.1 的计数，两组各 100 人，合格者分别 20 人与 60 人。每条比例条以该项分母为全长，依次比较全体申请者、按资格细分的人、已获选者。共同的真正例率 $t = 0.8$ 与假正例率 $f = 0.1$ 满足均等化赔率，却使另外两项比例不同。此冲突依赖不同基准比例与 $0 < f < t < 1$ ； $f = 0$ 等边界情形需另行分析。




图 13.3 示例 13.1 中两个群体的完整计数。行按真实资格划分，列按是否获选划分；下方各比例使用不同分母。两组真正例率和假正例率相同，获选比例与正预测值却不同。图只使用该教学例子的计数，不包含预测概率，因此不能据此检验分数校准。

预测概率。假设在两组获选者中各有 10 人得到 0.8 分，其中实际合格人数分别为 8 人和 6 人，则这个分数组中的实际比例是 0.8 和 0.6：第一组的经验频率与该分数一致，第二组的经验频率比该分数低 0.2。这与上例给出的总体计数可以同时成立；是否存在总体失准，仍需结合样本量评估估计误差。分数校准检验提供了二元错误率没有包含的信息，也不能被“真正例率相同”替代。

在实际审计中，应根据选定准则保存各组的混淆矩阵与分数。机会比例用组内获选人数除以组内总人数，真正例率用合格且获选人数除以合格人数，正预测值则用合格且获选人数除以获选人数；校准检验按组和分数区间比较平均预测与实际频率。这些统计量可以来自同一批记录，却因条件

和分母不同回答不同问题。将差值与事先确定的容许差异比较之前，还要检查估计误差，见第 13.2.7 节。

交叉群体中的分数检验 第 13.2.1 节中细化比较人群的思路也可以用于检查概率分数。**多重校准** (multicalibration) 要求预测在一族可识别子群的各个分数区间内，都与实际频率大致一致。Hébert-Johnson 等提出这一要求，以避免总体校准掩盖复杂子群中的系统性偏差⁴。

沿用第 11.2 节的分箱检验，对分数区间 B 和子群 g 可检查

$$|\mathbb{E}[y - p(\mathbf{x}) \mid g(\mathbf{x}, a) = 1, p(\mathbf{x}) \in B]| \leq \varepsilon. \quad (13.3)$$

这里还需给出参与检查的最小群体质量及区间划分，避免对几乎没有样本的条件作不可能的精确要求。实际检验把条件期望替换为对应样本中的平均残差，并为所搜索的子群和分数区间报告误差范围。这并不要求各组成功率相同，而是要求模型不要持续高估或低估它能够识别的子群。

13.2.3 相似个体的处理差异

群体平均可能掩盖组内差异。**个体公平** (individual fairness) 要求任务相关条件相近的个体获得相近处理。这个要求把困难转移到“相关”和“相近”的定义：使用什么距离、哪些因素合理、哪些因素不应参与，都需要说明。

Dwork 等在 Fairness Through Awareness 中将这一要求表达为相似性约束。设 $q_{\mathbf{x}}$ 是对申请者 $\mathbf{x}$ 采取各种决策的概率分布， $d(\mathbf{x}, \mathbf{x}')$ 表示任务认可的个体差异， D 衡量决策分布差异，则要求

$$D(q_{\mathbf{x}}, q_{\mathbf{x}'}) \leq d(\mathbf{x}, \mathbf{x}'). \quad (13.4)$$

这一判定限制相近者之间的决策概率差异。二元决策若用总变差距离，左侧就是两人的录取概率之差的绝对值⁵。

例如两人的任务距离为 0.05，录取概率却分别为 0.9 和 0.1，就违反了上述条件；分别为 0.60 和 0.63 则符合这一对个体的要求。这一定义比群体平均更细，但距离并非免费获得。若把历史收入差异直接写入距离，历史机会不平等可能被当成“本来就不同”。某个距离下通过检验，只能支持相对于该距离的公平结论。随机化能帮助满足平滑的相似性要求，也意味着同等个体在一次抽签中仍可能得到不同结果；这一公平约束针对的是事前分布。

检验个体公平需要先固定任务距离和决策分布的估计方式，再搜索差异过大的个体对。对每一对记录可计算 $D(q_{\mathbf{x}}, q_{\mathbf{x}'}) - d(\mathbf{x}, \mathbf{x}')$ ，正值就是违反式 (13.4) 的证据。若模型直接提供随机化决策的概率，可据此计算；若

⁴ Ú. Hébert-Johnson, M. Kim, O. Reingold, G. Rothblum, *Multicalibration: Calibration for the (Computationally-Identifiable) Masses* In Proceedings of the 35th International Conference on Machine Learning, 2018, pp. 1939–1948

⁵ C. Dwork, M. Hardt, T. Pitassi, O. Reingold, R. Zemel, *Fairness Through Awareness* In Proceedings of the 3rd Innovations in Theoretical Computer Science Conference, 2012

只能重复调用随机化接口, 则需估计这些概率及其误差。测试若只覆盖有限个体对, 应报告搜索范围和最大已发现违规量, 不能把未发现违规写成所有个体对均满足约束。群体平均检验与这种成对检验相互补充, 前者通过并不推出后者通过。

可以用四个人看出这种不互推。两组各有一名高资格者和一名低资格者, 第一组录取高资格者, 第二组录取低资格者。两组录取率都为二分之一, 但同等资格者受到相反处理, 因此人口统计均等并不保证个体公平。反过来, 换成高资格者比例不同的两个群体, 若规则一致地录取所有高资格者, 而且任务距离将同等资格者之间的距离设为 0、高低资格者之间的距离设为 1, 式 (13.4) 就能成立; 两组高资格者比例不同, 仍会得到不同录取率。个体要求依赖的是任务距离, 人口统计均等依赖的是组内总体比例, 两者保护的关系不同。

13.2.4 决策依据与影响路径

若关注的是不合理因素通过何种路径影响决策, 就需要进一步建立因果模型。**反事实公平** (counterfactual fairness) 比较同一个人在不同群体属性设定下的预测, 而不是拿两个现实中的人直接作比较。Kusner 等的定义固定用于刻画个体的外生背景, 再考察对群体属性作干预后预测分布是否改变⁶。

设 $\mathbf{u}$ 为因果模型中的外生变量, $\hat{y}_{a \leftarrow v}(\mathbf{u})$ 表示把群体属性设为 v 时得到的预测。用 a_0 表示当前个体实际观测到的群体属性值, 避免与外生变量混淆。对于实际观测 $(\mathbf{x}, a = a_0)$, 一种标准写法是对所有可取值 b, v 要求

$$\begin{aligned} \mathbb{P}(\hat{y}_{a \leftarrow a_0}(\mathbf{u}) = b \mid \mathbf{x}, a = a_0) \\ = \mathbb{P}(\hat{y}_{a \leftarrow v}(\mathbf{u}) = b \mid \mathbf{x}, a = a_0). \end{aligned} \quad (13.5)$$

条件中的实际观测用于推断外生背景, 干预后的世界再由同一因果机制生成。这个顺序很重要: 只修改数据表的一列、把其后果变量全部固定, 通常不等于计算该反事实。

在一个构造模型中, 测验分数满足 $x = u + \gamma a$, 其中 u 表示需要评价的能力, γa 表示被认定不应影响分配的系统性因素。直接用 x 预测会随 a 改变; 若结构式和 γ 正确, 使用 $x - \gamma a = u$ 就消除了这条路径。若进一步设 $\gamma = 2$, 实际观测为 $a = 1, x = 7$, 则结构式推得 $u = 5$ 。干预为 $a = 0$ 后, 同一人的分数应变为 $x = 5$; 使用 x 作依据的规则可能改变决策, 使用 $x - 2a$ 的规则在两个世界都得到 5。不能只把输入中的 a 改成 0 而仍保留 $x = 7$, 因为那没有沿结构式传播干预的后果。这个例子也说明, 计算公平分数有时反而需要群体属性。若实际差异来自其他未观测原因, 机械减去 γa 便未必合理; 从观测分布通常不能唯一恢复上述结构。

⁶ M. J. Kusner, J. R. Loftus, C. Russell, R. Silva, *Counterfactual Fairness In Advances in Neural Information Processing Systems*, 2017

有些任务只禁止部分影响路径，例如允许与目标相关的实际能力影响录取，但禁止与任务无关的直接偏好。此时需要说明路径选择和识别假设，不能把“只改变群体属性后输出不变”当成适合一切任务的要求。后文第 15.5 节将讨论决策补救，它同样涉及反事实，但寻找的是个体能够实施的行动；本节比较的群体属性干预用于分析影响机制，不意味着这些属性是个体应当改变的行动。

这类判定所需的证据与群体统计、个体成对比较不同。需要明确因果图和结构方程，依据实际观测推断外生背景，再对同一背景分别生成属性干预前后的决策分布，比较式 (13.5) 两侧。因果机制无法由现有数据识别时，应报告在不同合理机制下结论是否改变；仅有一张群体混淆矩阵，不能验证反事实公平。由模型生成的反事实比较即使完全一致，结论也仍以该因果模型成立为条件。

13.2.5 生成内容中的社会表征

对于生成式培训建议，还需检查模型怎样描述不同人群。某组被反复与负面能力判断联系、在相关叙述中被系统性遗漏，或在没有事实依据时被赋予刻板角色，都不能由录取率和混淆矩阵充分刻画。应先明确要评价的表达及其语境，例如“证据不足时不按群体身份推断能力”，再建立可复核的内容标注规则。

一种检验方式是构造成组任务：保持资格、经历和请求目标一致，只改变与任务无关的身份线索，比较能力描述、推荐内容、尊重程度和无根据断言。同时保留证据充分与不充分两类条件，避免模型通过一律拒答获得表面一致。需要核查成组文本是否同样自然、是否改变了事实含义，再由明确的评分规则和必要的人工复核评价输出。更换身份词的文本比较只能支持相应行为差异，不能直接等同于前一小节中的个体因果反事实。

生成具有随机性时，应重复采样并报告各类输出的比例及其波动，检查不同提示与表达下结论是否保持。内容评价者或自动评分器本身也可能有偏差，需要用经过核查的样本检查评分一致性及典型误判。第 13.4 节以 BBQ 等工作进一步讨论如何把证据条件落实为生成任务的评价设计。

13.2.6 公平要求的声明

形成判定结论之前，应把“希望更公平”写成能够检查的要求。声明需要交代适用任务与人群、保护哪些群体或个体关系、认可什么资格标准、禁止哪些影响路径，以及优先改善哪一种后果。随后指定主要判定准则、容许差异、总体效用和资源限制，并说明采用哪些数据、在哪个时间范围内验证。这些内容共同决定怎样解释前述证据，单独给出一个公平指标还不是完整要求。

例如，可以为教学用培训分配系统声明：以独立核验的资格为 y ，对事先列出的两个群体优先限制合格者获选率的绝对差不超过 0.05，同时要求两组获选率在合格者中都不低于 0.8；名额总量不能超过预算，并同步报告假正例率、交叉群体差异及申请成本。数值只是教学设定，不是通用标准。差距约束限制不一致程度，最低水平要求约束绝对表现，在某组尚低于下限时，不能仅靠降低表现较好组的机会达标；若资源与这些要求不能同时满足，需要重新讨论目标或资源，不能隐去其中一项。

声明还应规定信息如何使用。例如，群体属性可在训练和审计时用于构造约束，但部署时是否允许读取该属性，要由任务要求明确决定。这会直接影响可选方法：组别阈值需要在决策时识别组别，而训练时采用公平约束并不必然要求部署模型读取群体属性。

目标声明与达成声明必须分开。前者说明系统打算满足什么，后者报告哪个模型版本在什么人群、数据和假设下获得了何种证据。独立检验未完成、关键群体样本不足或因果机制无法识别时，应保留这些限制，不能因为采用了某种去偏算法就宣称“模型公平”。

13.2.7 判定结论的形成

前五个方面提供了针对不同要求的证据。形成结论时，需要明确本次采用哪些要求、它们能否同时成立，以及现有样本和假设支持多强的判断。某个维度达标只能支持限定范围的结论，不应汇总为没有条件的“系统公平”。

准则之间的取舍 同一决策系统可能同时接受多种要求。出现指标分歧时，应先判断分歧是否来自准则本身，而不立即归咎于训练不足。下面在群体比较中给出几项可直接推导的冲突，它们约束的是能够共同选择的目标，不是检验公平性的额外方法。

例 13.1 已经显示同一批预测可以通过一种准则而不通过另一种。要区分这是偶然数值还是一般限制，可以从各组正例比例推导。记组内正例比例为 π_a 、真正例率为 t_a 、假正例率为 f_a ，由对真实资格分类求和，获选比例为

$$r_a = \pi_a t_a + (1 - \pi_a) f_a.$$

即使固定 $t_a = t$ 与 $f_a = f$ ，只要 $t \neq f$ 且组间 π_a 不同，机会比例仍然不同。若又要求 r_a 相同，就不能任意保留前述两个共同错误率。

对获选者反过来询问资格比例，会得到另一项限制。设各组满足相同的真正例率 t 和假正例率 f ，组 a 中的正例比例为 $\pi_a \in (0, 1)$ ，则获得正决

策者中的真正正例比例为

$$\mathbb{P}(y = 1 \mid \hat{y} = 1, a) = \frac{t\pi_a}{t\pi_a + f(1 - \pi_a)}. \quad (13.6)$$

当 $t > 0$ 且 $f > 0$ 时，右侧随 π_a 严格增加。因而基准比例不同的组，即使错误率已经相同，正决策的预测值仍然不同。这一具体结论不要求模型采用某种算法，也不适用于所有退化边界；例如 $f = 0$ 时正预测值可能均为 1。关于风险分数不同公平条件之间的更一般取舍，需保留相应条件理解⁷。

。

分数校准与错误平衡的冲突也能直接推导。设 $S = p(\mathbf{x}) \in [0, 1]$ 在每组校准， $\mu_{1,a} = \mathbb{E}[S \mid y = 1, a]$ 、 $\mu_{0,a} = \mathbb{E}[S \mid y = 0, a]$ 。若额外要求两类人的平均分数分别跨组相同，记为 μ_1 和 μ_0 ，则全期望给出

$$\pi_a = \mathbb{E}[S \mid a] = \pi_a \mu_1 + (1 - \pi_a) \mu_0.$$

两个组的 π_a 不同时，相减得到 $\mu_1 - \mu_0 = 1$ 。由于分数在 $[0, 1]$ 内，只能有 $\mu_1 = 1, \mu_0 = 0$ ，即正例几乎必然得 1 分、负例几乎必然得 0 分。这说明在不同基准比例、非完美预测的情形下，三项要求不能同时成立。这里的“平均分数平衡”不同于式 (13.2) 中的二元错误率相同，不能把两个论证的条件混在一起。

不可兼得关系并不意味着公平性无从讨论，而是要求在冲突出现之前说明优先保护什么。例如培训机会应优先避免遗漏合格申请者时，可以把机会均等作为主要约束，同时公开假正例率、名额总量和预测值的变化。此时没有选择的准则仍应报告，用来揭示代价；不能因为它不再是优化目标，就把相应差异从评价中删去。

有限样本与建模假设 公平准则给出了要检查的关系，实际数据只能提供有限证据。群体检验依赖样本覆盖和分母，个体检验还依赖所接受的距离，反事实检验则额外依赖因果机制。后两类假设即使样本增加也不会自动正确；应把假设敏感性与抽样误差分别报告。以下以群体差距为例说明怎样从估计值形成有边界的判定。

估计群体指标时应报告分母与样本量。机会均等的分母是组内正例数，假正例率的分母是组内负例数。小群体或交叉群体可能缺少足够样本；同时搜索许多群体又会增加偶然差异。敏感属性缺失时，补全属性的误差也会进入公平评价，不能将推断群体当作无误标签。

样本误差与实质差异是不同问题。设两个固定群体各有 n_u, n_v 个独立正例，其真正正例率估计为 $\hat{t}_u, \hat{t}_v$ 。将 Hoeffding 界分别用于两组再取联合界，

⁷ J. Kleinberg, S. Mullainathan, M. Raghavan, *Inherent Trade-Offs in the Fair Determination of Risk Scores* In arXiv preprint arXiv:1609.05807, 2016

以至少 $1 - \delta$ 的概率有

$$|(t_u - t_v) - (\hat{t}_u - \hat{t}_v)| \leq \sqrt{\frac{\log(4/\delta)}{2n_u}} + \sqrt{\frac{\log(4/\delta)}{2n_v}}.$$

即使总体样本很多，只要其中一组正例太少，差距的不确定性仍会很大。若要求绝对差距 $|t_u - t_v|$ 不超过容许值 η ，应将经验绝对差 $|\hat{t}_u - \hat{t}_v|$ 加上上式右侧的误差界，再检查所得上界是否不超过 η ；“没有拒绝零差异”并不能证明实际差异很小。若群体是在同一数据上反复搜索出来的，还需单独验证或控制整个搜索族的误差。

达标、违反与证据不足 对于已声明的差异上限，应根据估计范围区分三种结论：差异的可靠上界仍不超过容许值，支持在相应条件下达标；可靠下界已经超过容许值，支持存在违反；估计范围跨过界限，则证据不足。个体比较还要报告距离定义和搜索范围，因果比较要报告机制假设，内容比较要报告任务与评分条件。不能把“未找到违规”或“差异不显著”直接写成已经公平。

判定报告应保留各组原始水平、使用的准则、检验数据与模型版本，并说明未覆盖的人群和未核实的假设。这里得到的是干预的目标与证据：哪些要求没有满足、在哪些人群或条件下失败。至于应补充数据、重训模型还是调整服务流程，还需结合前节的形成原因决定。

13.3 公平性的干预

公平判定指出哪些要求没有满足，干预要进一步确定应该改变哪个环节。同一机会差距可能来自群体数据缺失、标签不合理、训练时忽视少数样本，也可能来自分数到行动的规则。因此，应依据已经声明的要求和形成原因，选择数据、训练或决策流程上的措施，不能看到差距便直接更换算法。

前一节已经确定保护对象、准则、容许差异和证据边界。下面三类实施方向分别回答：学习依据是否需要修正，模型学到的规则是否需要调整，以及既有分数怎样转化为恰当服务。它们可以组合。例如补齐小群体数据后仍需调整错误成本；训练约束达标后仍需检查等待与申诉负担。效果验证与持续调整则检查这些措施是否真正改善了目标人群的处境。

图 13.4 按发生位置区分这些改变：数据阶段修正学习依据，训练阶段改变学习规则，决策阶段改变固定分数如何转为服务。这三类措施可以组合；如果问题发生在另一个环节，仅调整当前环节指标未必能纠正后果。




图 13.4 公平干预发生在数据、训练或决策阶段。补覆盖、核标签、风险与公平约束、随机阈值分别表示不同措施；虚线记录的标签未知， $\hat{y}$ 是预测决策。决策阶段独立于真实标签等概率选择两个阈值，数值构造见示例 13.2。三类措施可组合，单项达标不保证完整系统公平。

13.3.1 数据采集与质量的改进

若诊断表明问题来自看不见某些人，干预重点是扩展采集渠道与覆盖范围。可以按目标人群、业务条件和交叉群体检查缺口，对缺少的语言、设备、地区或资格区间有目的地补充样本。采集“更全面”应落实为哪些条件此前缺少证据、现在增加了多少有效观测，而不只是把每组人数做成相同。重复抽取旧样本会改变训练频率，却没有带来新的个体信息。

补充数据还需区分训练与评价职责。训练可以为困难或少数群体增加样本，评价则要说明结果对应目标人群还是刻意平衡后的审计人群。若采样比例改变，直接平均会改变总体指标的含义；应保留分组结果，必要时按已知目标构成汇总，并说明权重依据。新的审计样本应尽量独立于用于选择干预方法的数据，避免把反复调试后的效果当作独立证据。

若问题来自测量，应检查同一字段在不同群体中是否表达同一种任务信息。可以对不同语言或设备条件进行配对核验，与更可靠的测量参照比较，区分真实差异与测量误差。若问题来自标签，则需要重新核对资格标准、标注指南和争议样本，必要时重新标注。不能为使群体比例一致而任意改写真实结果；要改变的是错误记录或不合理的目标定义，并保留变更依据。

标签缺失又是另一种情形。对只有获选者才有后续成绩的任务，不能把未获选者记为失败；可以寻找独立资格测验、适当的后续调查或其他有依据的观测来源。若采用改变选择机制的方式获取新证据，需要说明实施条件；依靠统计校正则要核查选择概率与识别假设，具体限制见第 13.3.4 节。增加已有获选者的记录并不能自动填补被拒者的信息缺口。

数据修正应留下可追溯记录。Gebru 等提出的数据集说明书记录数据的用途、构成、采集过程和适用范围，为检查遗漏人群及不适当使用提供依

据。文档帮助定位问题，但不能替代实际补采、测量核验或标签修正⁸。

数据质量改善为公平学习提供更好的依据，却不自动决定资源应如何分配。若标签和覆盖已经合理，而训练仍允许牺牲小群体来换取总体收益，就需要改变学习规则；若问题发生在分数转为行动的环节，则要继续检查决策流程。

13.3.2 训练目标与学习规则的调整

当问题来自模型怎样使用已有数据时，可以改变不同错误在训练中的代价、限制表示中传递的信息，或直接约束所选公平指标。这些措施共同改变学得预测规则，但作用对象不同。重加权照顾哪些样本被目标函数重视，表示约束限制怎样编码依据，显式公平约束则直接反馈某项要求的违规量。

学习阶段可以将公平要求写为约束。设 $R(f)$ 为任务风险， $\Delta(f)$ 为已经选定的公平差异指标， η 为容许差异，则求解

$$\min_f R(f), \quad \Delta(f) \leq \eta$$

明确了任务目标与限制。使用 $R(f) + \lambda \Delta(f)$ 的惩罚形式便于优化，但给定 λ 不自动保证约束达标；仍需在独立数据上验证。

任务效用与公平约束需要共同比较。图 13.5 在一个构造的 200 人数据集上，把 $\Delta(f)$ 具体取为两组真正例率之差的绝对值。一个候选在这两项上都不差、且至少一项更好时，就支配另一个候选；没有被当前候选集中的其他模型支配的方案组成该候选集的帕累托集合。这是有限比较的结论，扩大候选模型、改变指标或重新评价后，集合都可能变化。

不同样本与错误的训练代价 重加权改变的是训练目标中每组的相对贡献。假设训练集中两组样本数为 n_u, n_v ，总数 $n = n_u + n_v$ ，希望每组对经验损失各占一半，可以将组 a 的每个样本赋权 $\omega_a = n/(2n_a)$ 。此时

$$\frac{1}{n} \sum_{i=1}^n \omega_{a_i} \ell(f(\mathbf{x}_i), y_i) = \frac{1}{2} \hat{R}_u(f) + \frac{1}{2} \hat{R}_v(f),$$

其中 $\hat{R}_a$ 是组内平均损失。实际做法是根据训练集确定权重，在每次梯度计算中按权重累加样本损失，再在独立数据上重新计算已选公平指标。它让小群体不会只因人数少而被目标函数忽视，却不自动使两组错误率相同，也不修正错误标签。是否采用各占一半的目标仍须由任务要求决定。

表示中的信息依赖 若同一套特征将被多个预测器使用，可以在表示层减少不希望传递的群体信息。Zemel 等的 Learning Fair Representations 用软

⁸ T. Gebru, J. Morgenstern, B. Vecchione, J. W. Vaughan, H. Wal-lach, H. Daumé III, K. Crawford, *Datasheets for Datasets* In arXiv preprint arXiv:1803.09010, 2021




图 13.5 准确率与公平差异的有限候选比较。两组各 100 人，每组均有 50 名合格者；五个候选的指标由构造混淆计数计算，A、B、C 的差异与准确率为 (4 百分点, 75%)、(10 百分点, 83%)、(20 百分点, 90%)，D 与 E 分别为 (16 百分点, 80%) 与 (24 百分点, 86%)。B 支配 D，C 支配 E，空心圆标出当前五个候选中的不可支配方案。虚线只引导读者沿这三个候选阅读前沿，不保证连线上存在可实现的中间候选。

分配把样本映射到一组原型，同时权衡输入重构、标签预测和不同群体的原型分配差异。这里不是简单删除一个字段，而是检查变换后的表示是否仍以相近方式编码不同群体⁹。

设 $q_k(\mathbf{x})$ 为输入分配给第 k 个原型的概率， $\bar{q}_{k,a}$ 为组内平均分配概率，一个便于理解的公平惩罚是 $\sum_k |\bar{q}_{k,u} - \bar{q}_{k,v}|$ 。如果之后先按 q_k 抽取一个原型，再仅根据原型作决策，且每个原型的组内平均分配相同，那么由全概率公式可以得到相同录取率。但有限样本上的近似相同，或者直接将整个软分配向量交给任意下游模型，都不能无条件继承这个结论。表示经过不同使用方式后，需要重新检查保护目标。

这类表示干预在训练时需要同时调整原型、样本到原型的分配以及基于表示的任务预测器。输入重构损失限制“丢掉所有信息”的退化解，标签预测损失保留任务所需区分能力，群体分配惩罚则减少指定的信息差异。三项权重确定取舍，训练后在独立数据上分别检查任务效用、表示中的群体可预测性和最终决策的公平指标；仅看到训练时分配惩罚减小，还不能断言下游使用已经公平。

另一条路线是让一个辅助预测器主动寻找残留的群体信息。**对抗去偏** (adversarial debiasing) 在训练任务预测器时，同时训练一个根据其输出或中间表示预测群体属性的对手。Zhang 等将这种相互竞争用于降低特定公平差异；其作用取决于对手看见什么信息，以及它是否足够强¹⁰。

⁹ R. Zemel, Y. Wu, K. Swersky, T. Pitassi, C. Dwork, *Learning Fair Representations* In Proceedings of the 30th International Conference on Machine Learning, 2013, pp. 325–333

¹⁰ B. H. Zhang, B. Lemoine, M. Mitchell, *Mitigating Unwanted Biases with Adversarial Learning* In arXiv preprint arXiv:1801.07593, 2018

若用 h_θ 表示待学习输出, d_ϕ 表示群体预测器, 一个概括这种竞争的目标是

$$\min_{\theta} \max_{\phi} \{L_{\text{task}}(\theta) - \lambda L_{\text{group}}(\theta, \phi)\}.$$

对手通过减小群体预测损失寻找漏洞, 任务模型则试图增大对手的最优损失。训练时交替进行两类更新: 固定任务模型, 用真实群体属性训练对手; 再固定对手, 以降低任务损失、增大群体预测损失的方向更新任务模型。部署后通常只保留任务模型。评价时还应另训独立的群体预测器, 检查信息是否只是绕过了训练中的对手。只让对手观察输出, 对应消除输出与群体的依赖; 若追求均等化赔率, 需要处理给定真实标签后的剩余依赖, 例如在各标签层内训练对手。对手未超过基准预测水平, 只能支持相对于其能力与训练过程的判断, 不能证明不存在更强的群体推断器。对抗优化不稳定、任务信息与群体信息重叠, 都可能使准确性与公平目标发生取舍。

公平约束下的分类学习 表示学习通过改变信息间接影响公平性; 若保护标准已经明确, 还可以直接优化相应条件矩。Agarwal 等把公平分类归约为一系列**成本敏感分类** (cost-sensitive classification) 问题, 即为不同样本的不同错误赋予不同代价, 再调用已有分类学习器。归约允许学习器保持自身表示形式, 而把公平要求放在外层求解¹¹。

将选定的经验公平约束拆成条件矩差的单向限制, 写为 $\hat{g}_j(f) \leq \eta_j$, 这样约束量对分类器的随机混合保持线性。对分类器上的随机混合分布 Q , 可构造

$$\min_Q \sup_{\lambda \geq 0} \left\{ \mathbb{E}_{f \sim Q} [\hat{R}(f)] + \sum_j \lambda_j (\mathbb{E}_{f \sim Q} [\hat{g}_j(f)] - \eta_j) \right\}. \quad (13.7)$$

这是解释约束作用的拉格朗日形式; 具体算法还会限定乘子的搜索范围与停止精度。乘子提高某项违规的代价, 分类学习器则在调整后的成本下寻找更好的预测器。多轮得到的分类器可以混合, 使无法由单个确定规则达到的中间错误率成为可达目标。

以提高某组真正例率为例, 外层可以增大该组正例被误拒的成本, 使学习器更愿意将这些样本判为正例。若这又明显增加假正例率, 另一项约束的乘子会抑制这一变化。这个过程比“公平惩罚越大越好”更具体: 每项约束对应哪些样本、哪些错误, 可以追踪。

实施时, 可从一组初始乘子出发训练成本敏感分类器, 计算每项经验约束的违规量, 再增大被违反约束的乘子, 重复学习并保存所得分类器。最终按求得的混合权重组成规则, 而不是只挑训练准确率最高的一轮。这里直接反馈的是保护准则的违规量; 前述对抗去偏反馈的是群体信息是否仍可预测。两者有时都能减少某项群体差距, 却不能仅凭采用了同一种优化

¹¹ A. Agarwal, A. Beygelzimer, M. Dudik, J. Langford, H. Wallach, *A Reductions Approach to Fair Classification* In Proceedings of the 35th International Conference on Machine Learning, 2018, pp. 60–69

形式便视为相同方法。

归约的优化性质以成本敏感学习器的求解能力、候选分类器族和允许的优化误差为条件。经验约束达标也不等于总体约束必然达标，仍需独立评价和适当容差。群体属性可以只用于训练时构造约束，部署时分类器使用哪些特征由所选模型族决定；这与必须在使用时读取群体属性的组别后处理有所不同。

当保护对象包括大量交叉群体时，无法总在训练前列完每一项约束。Kearns 等的学习与审计交替方法让审计器搜索当前分类器加权违规量最大的子群，再由学习器针对反馈修改分类器。这与第 13.2.1 节的审计使用同一种参考总体、概率质量和差异证据，但这里把发现的违规转为下一轮学习约束。每轮改善一个子群可能影响另一个交叠子群，停止时仍须检查约定的整个群体族，并在未参与迭代的数据上验证。

若声明的是个体公平，则可以在任务距离明确的条件下，对相近个体的决策分布增加一致性约束，或惩罚超过允许距离的差异；训练后仍要用未参与优化的个体对检验。若声明的是反事实公平，则需要依据已认可的因果模型构造不受被禁止路径影响的预测依据，或约束相应反事实世界中的预测一致性。前述测验例子中使用 $x - \gamma a$ 就是在特定结构成立时构造依据的一种方式；机制假设不可靠时，单纯优化一致性不能使因果结论可靠。这两类要求不应被总体群体比例相等替代。

13.3.3 决策规则与服务流程的调整

模型无法重训时，仍需区分修改的对象：分数失准可以在输出分数上作修正，机会与错误率不符合约束则需要改变从分数到行动的规则。这两种操作可能相互影响，但一个目标达标并不推出另一个目标达标。

针对式 (13.3) 中的失准，一个直观的多重校准修正过程是在“子群与分数区间”中按平均残差调整预测，再检查其他交叠群体。正式算法还要控制调整步长、搜索代价和泛化误差。分数修正后必须重新检验各组校准；若下游使用固定阈值，修正还可能改变谁获得机会，因此也要重算相应的分配指标。

如果保留原分数，只修改决策规则，可以按群体选择阈值。对每个群体改变阈值会得到一系列假正例率与真正例率坐标，即 ROC 曲线上的点。随机选择两个阈值，对应两点的凸组合。Hardt 等的后处理利用这些可达区域，在满足均等化赔率的共同坐标中选择合适的误差水平。

示例 13.2 随机化如何补出共同错误率 假设在独立验证数据上，第一组的两个阈值分别得到 $(f, t) = (0.1, 0.5)$ 和 $(0.3, 0.9)$ ，第二组某个阈值得到 $(0.2, 0.7)$ 。对第一组以各一半概率使用两个阈值，期望错误

率成为 (0.2, 0.7), 从而与第二组一致。随机化必须独立于尚未观察的真实标签; 部署后仍需检查这些验证率能否代表实际分布。

如果两组共同可达的区域很差, 后处理可能主要通过降低较好组表现实现均衡。它不能创造原分数中没有的区分信息, 也不保证满足个体公平: 两个任务条件相近的人, 可能因为组别阈值不同而获得不同录取概率。后处理的优点是可清楚计算固定分数上的取舍, 限制则是同时固定了已有表示与排序。是否使用这种规则, 必须结合允许的信息使用、资源约束和受影响者的实际处境判断。

决策干预还包括模型之外的服务过程。对模型难以可靠处理的申请, 可以设置复核、补充材料与纠错入口, 并记录处理标准和完成时间; 对申请渠道本身的障碍, 可以改善语言支持或材料提交方式。人工参与并不自动保证公平, 仍要检查不同群体进入复核的比例、等待负担和最终结果。若某组被大量转交人工而得不到及时服务, 就不能只因自动预测中的错误减少而宣称改善。

对于生成式建议, 可以在输出与服务规则中明确应依据什么事实、何时请求补充信息、哪些表述需要复核, 并在前述成组任务上检查这些调整的效果。训练阶段也可利用经核查的对照样本或反馈调整行为, 但“使用了去偏数据”与“已满足内容公平要求”仍是两个不同结论。

13.3.4 干预效果与持续调整

数据、训练与流程上的措施都必须回到同一份公平要求接受检验。即时检验比较修改前后是否改善, 长期跟踪则检查干预改变数据与人群状态后是否仍然有效; 二者共同决定是否保留、调整或撤回措施。

即时效果与负担转移 干预效果需要相对于明确的对照判断。应固定任务、保护群体、标签定义和主要公平准则, 在未用于选择措施的数据上, 用同一批样本评价干预前后的模型或规则; 若干预已经改变人群和标签生成过程, 就需要后文讨论的额外识别条件。报告应同时包括总体效用、各组指标和保护目标, 并给出变化量的误差范围。例如, 机会均等的差距从 0.2 降为 0, 可能来自较差组的真正例率由 0.6 提高到 0.8, 也可能来自较好组由 0.8 降为 0.6。仅报告差距会把这两个结果写成同样的改善。应同时保存两组原值、新值、假正例率和名额数量, 再判断变化是否符合目标。还应检查是否把错误负担转移到另一个群体或另一个环节。

对拒答系统, 需要把第 11.2 节中的自动处理比例按群体报告, 并与各组接受部分的风险一起比较。若某组的自动预测错误率降低, 只因为该组大量请求被拒绝, 结论就不能写成“服务更加公平”。拒答后的等待、人工

成本和结果也属于干预效果；这里的服务覆盖是获得处理的比例，不是预测集合包含真实标签的覆盖率。

选择措施与报告效果应使用职责明确的数据。若反复选择最有利的公平指标，容易只展示局部改善。主要标准应由使用要求确定，其他指标用于揭示代价和边界。效果不确定时，应明确样本限制，而不是把差异不显著解释为已经消除不公平。

选择性标签与后续结果 即时评价固定比较条件，检查干预当时改善了什么。长期评价还要考虑干预改变条件本身：一次分配会改变下一轮可见的数据和资源。推荐系统增加某些内容的曝光后，会获得更多点击证据；培训名额分配提高某些人的能力后，又改变未来的资格分布。因此，即使静态指标改善，也需要检查长期机会、能力与负担的演化。

在选择性标签条件下，可以记录选择概率，并在条件可交换、正概率覆盖等假设下使用相应加权估计；若从未给某类申请者机会，就无法仅靠这种加权恢复其结果。需要有目的地补充证据，并检查数据获取方式是否符合使用要求。

Lakkaraju 等系统研究了选择性标签给预测评价带来的困难，并利用不同决策者的选择差异构造评价证据。其意义在于指出，验证集的标签生成过程本身可能与待评价决策有关；决策者差异也只有在相应比较假设下才能支持推断，不能被自动视为随机实验¹²。

为区分即时资格与后续收益，本段用 z 表示培训后的结果，而不再沿用前文的资格标签 y 。令 $r = 1$ 表示获得培训， $z(1)$ 表示接受培训时的潜在结果， $e(\mathbf{x}, a) = \mathbb{P}(r = 1 \mid \mathbf{x}, a)$ 。若给定 $(\mathbf{x}, a)$ 后，选择 r 与 $z(1)$ 独立，且目标人群中 $e > 0$ ，还满足接受培训时观测结果 $z = z(1)$ ，则

$$\mathbb{E}\left[\frac{rz}{e(\mathbf{x}, a)} \mid a\right] = \mathbb{E}[z(1) \mid a]. \quad (13.8)$$

左侧的乘积在 $r = 0$ 时定义为零，不需要观测被拒者的 z 。证明只需先条件于 $(\mathbf{x}, a)$ ：选择独立性使加权项的期望等于该条件下的潜在结果期望，再取组内平均。若审核者使用了数据中没有记录的重要信息，独立性就可能失败；若选择概率很小，权重会放大估计方差。这些限制比“做一次重加权”更决定结论是否可信。

长期问题还不止于标签缺失。Liu 等的 Delayed Impact of Fair Machine Learning 用一个决策后状态变化模型分析群体受到的后续影响，表明在其模型假设下，静态公平约束可能帮助也可能损害原本希望保护的群体。决定影响方向的是谁被新增选中、选择如何改变其未来状态，以及群体原有分布¹³。

可以用一个明确构造的例子理解这种机制。若对某类申请者提供一项

¹² H. Lakkaraju, J. Kleinberg, J. Leskovec, J. Ludwig, S. Mulinathan, *The Selective Labels Problem: Evaluating Algorithmic Predictions in the Presence of Unobservables* In Proceedings of the 23rd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 2017, pp. 275–284

¹³ L. T. Liu, S. Dean, E. Rolf, M. Simchowitz, M. Hardt, *Delayed Impact of Fair Machine Learning* In Proceedings of the 35th International Conference on Machine Learning, 2018, pp. 3150–3158

机会，成功后状态增加 1，失败后因成本增加而减少 2，成功概率为 p ，则接受机会的期望变化是 $p - 2(1 - p) = 3p - 2$ 。当 $p = 0.5$ 时，扩大该类人的机会数量却使每名新增参与者的期望状态变化为 -0.5 。这不是现实培训的经验结论，而是在说明：只有新增正决策在目标人群和当前决策规则下具有正的条件期望净收益时，“多给机会”才会提高这个模型中的群体平均状态。若要进一步声称每个人都会改善，还需要更强的个体层条件。提供费用补助、调整课程或降低失败代价，可以改变这一结果，不必只在录取阈值上作选择。

持续干预应由已经说明的标准和新证据驱动。出现新的群体差异时，应回到形成机制判断是数据变化、测量变化还是干预副作用，再调整措施，而不是只对当前差距继续加大惩罚。

13.4 前沿研究

前文已建立分类、生成内容及服务过程的基本判定方法。面向生成模型与连续服务，相关研究进一步考察三个问题：开放文本中的伤害如何转化为可检验证据，不同指标的结论是否稳定，以及一次输出之外的完整服务是否公平。它们分别扩展判定对象、测量可信度和影响范围。

13.4.1 生成任务的证据条件与刻板印象

生成内容的成组检验需要保持资格、经历与请求目标一致，只改变无关身份线索，基本方法见第 13.2.5 节。进一步构造评价时，还要控制模型究竟掌握了多少事实：缺少依据时是否诉诸刻板印象，与已有依据时是否忽略事实，是两种不同的失败。

Parrish 等提出的 BBQ 问答基准把公平评价与证据条件联系起来：信息不足时，模型是否用群体刻板印象代替未知；信息充分时，模型是否仍让刻板印象压倒明确事实。基准使用成组构造的问题控制这些条件，覆盖美国英语情境中的九类社会维度。它提供了可比较的评价设计，但其文化和语言范围也限制了结论可以推广到哪里¹⁴。

例如在一个自构教学问题中，只知道两名来自不同地区的申请者都参加了测验，却不知道成绩，询问谁更适合培训时，模型应承认信息不足。若补充其中一人的成绩已经满足明确资格标准，模型又不应只因地区身份而忽略这条证据。两个条件共同区分“减少无根据的偏见”与“拒绝使用已经充分的事实”。仅靠总是回答“不知道”，可能降低某类偏见计数，却没有获得有用且公平的问答能力。

成组比较也不是自动有效的因果实验。更换身份词可能改变代词指代、语法、职业背景或文本自然程度，导致比较同时改变多个因素。评价需要人工核查语义等价性，报告事实性任务表现与群体差异，并区分模型主动

¹⁴ A. Parrish, A. Chen, N. Nangia, V. Padmakumar, J. Phang, J. Thompson, P. M. Htut, S. R. Bowman, *BBQ: A Hand-Built Bias Benchmark for Question Answering* In Findings of the Association for Computational Linguistics: ACL 2022, 2022, pp. 2086–2105

生成的内容、提供候选答案时的选择以及回答拒绝。不同接口观察的是不同的行为，不能把一种接口上的改善直接写成整个模型已经消除偏见。

13.4.2 评价结论对指标选择的敏感性

即使保持同一模型，不同指标也可能给出不同排序。Asgari 等在八个大语言模型、七种偏见指标和九个语料上的研究，用指标一致性分数与模型一致性分数分析这种差异，观察到一些同类指标也未表现出预期的一致关系。其结果支持在这组模型和语料中检查评价结论对指标选择的敏感性，而不是认为存在一个已经确定的通用偏见排名¹⁵。

指标不一致至少可能来自两种原因：一种是估计噪声、提示变化或测试数据差异，另一种是指标确实关注不同伤害。毒性表达减少，不能推出职业刻板印象减少；文本概率偏好减弱，也不必然改变最终生成。前一种情况需要提高测量稳定性，后一种情况需要分别报告并说明保护目标。直接把若干量纲不同的分数求平均，会隐藏分歧来源，也可能掩盖某个群体上的严重失败。

¹⁵ A. Asgari, H. Wu, A. Naziri, M. Kolaoudouzi, L. Seyyed-Kalantari, *Quantifying Metric and Model Agreement in Bias Evaluation of Large Language Models* In Proceedings of the 64th Annual Meeting of the Association for Computational Linguistics, 2026, pp. 16868–16933

13.4.3 连续服务中的负担与结果

输出文本的公平评价仍没有覆盖用户完成整项任务的经历。长期交互还使公平性与适应策略相连。个性化可以提高服务效果，也可能使某些群体更难获得纠正模型的机会。未来评价需要把输出内容、实际服务覆盖和反馈后的影响连接起来，并区分技术上可测量的差异与需要共同决定的价值标准。

对于代办申请或提供培训建议的智能体，一次回答只是服务链中的一步。即使推荐文本相近，不同用户可能面对不同的澄清轮次、等待时间和转入人工概率。可以沿用本章的判定思路，先定义完整任务的成功与负担，再按群体分析每一步的流失及最终结果。这里与第 14 章的行为监督相接：监督不只检查是否出现禁止性内容，还要检查系统是否持续把更多服务成本转移给某些用户。

13.5 本章小结

回到培训名额分配，公平性需要先说明什么差异有合理依据，再检查机会、错误、个体待遇、影响路径与社会表征是否符合要求。群体比例、个体成对比较、因果反事实与生成内容评价分别提供不同证据；指标之间可能冲突，有限样本及距离、因果和评分假设又限制结论强度。因此，应给出限定任务与人群的达标、违反或证据不足结论，而不能用一个总分替代全部判断。

公平要求确定后，还需要追查不合理差异发生在哪个环节。遗漏人群需

要补充覆盖，测量与标签偏差需要修正依据，训练目标的偏重需要调整学习规则，阈值与服务负担则需要改变决策流程。这些措施能够组合，却不能互相替代。最终要同时检查各组原有水平、干预后的实际收益与长期反馈，避免通过降低服务或转移负担获得表面均等。公平干预也揭示了一个更一般的问题：即使某项指标已经改善，系统仍可能没有实现它原本代表的要求。下一章将从公平约束扩展到更一般的任务目标和行为边界，讨论怎样监督、保持和干预模型行为。采集与审计所需的群体信息则还要受到隐私保护，其边界见第 16 章。

延伸阅读 Hardt 等关于机会均等与后处理的工作、Dwork 等关于个体公平的工作，分别从群体条件率和任务相似性刻画保护要求。两者适合与本章的指标冲突一起阅读，以辨认不同准则保护的对象及其不可互推之处¹⁶。

。

若关注决策依据和长期后果，可继续阅读 Kusner 等人的反事实公平与 Liu 等人的延迟影响分析。前者依赖因果模型刻画允许路径，后者说明静态约束的效果取决于决策怎样改变后续状态；两者都要求把建模假设与经验统计分开¹⁷。

¹⁶ M. Hardt, E. Price, N. Srebro, *Equality of Opportunity in Supervised Learning* In arXiv preprint arXiv:1610.02413, 2016; C. Dwork, M. Hardt, T. Pitassi, O. Reingold, R. Zemel, *Fairness Through Awareness* In Proceedings of the 3rd Innovations in Theoretical Computer Science Conference, 2012

¹⁷ M. J. Kusner, J. R. Loftus, C. Russell, R. Silva, *Counterfactual Fairness* In Advances in Neural Information Processing Systems, 2017; L. T. Liu, S. Dean, E. Rolf, M. Simchowitz, M. Hardt, *Delayed Impact of Fair Machine Learning* In Proceedings of the 35th International Conference on Machine Learning, 2018, pp. 3150–3158

目标对齐与行为约束

用户要求助手整理邮件，并希望重要内容得到保留。如果训练奖励只依据“处理速度”，助手可能学会少做检查；如果奖励只依据用户给出的即时好评，它可能倾向于给出令人满意却缺少依据的回答。这里没有外部攻击，模型仍可能偏离实际要求，因为学习过程优化的是可观察反馈，而用户关心的是行动后果。

上一章把公平要求落实为可检验的分配目标与干预规则。类似地，邮件助手也需要区分希望实现的结果、用于训练的反馈与行动时不得越过的边界。

在第 10 章的三层架构中，目标对齐与行为约束主要属于系统属性或规范要求层：它们规定系统应追求什么、哪些行为不可接受。对这些要求的评估与监督位于证据能力层；执行权限、模型更新后的重新验证与对监督盲点的主动利用，则需要在威胁与生命周期治理层处理。

本章从目标与约束的含义出发，说明行为偏离有哪些表现，以及可以用什么证据评估和监督。监督发现的规律还需要经受新任务、长交互和模型更新的考验，因此随后讨论行为泛化与约束保持依赖哪些条件，再按训练、推理和执行等位置介绍具体干预。监督提供判断，泛化分析说明判断和约束能延伸到哪里，干预则改变行为及其后果。

14.1 目标对齐与行为约束的基本概念

14.1.1 目标对齐与行为约束的含义

目标对齐 (alignment) 关注模型学到的行为能否符合预定的实际目标，而不只是获得较高训练分数。例如，整理邮件的目标可以是减少查找负担，同时保留重要内容；“收件箱变空”只是容易测量的结果，未必等于完成这一目标。对齐要求说明目标由谁提出、适用于谁，以及不同要求冲突时如何处理。

行为约束 (behavioral constraint) 规定模型采取行动时必须满足的条件或不得越过的边界。例如，只能操作本次授权的邮件、不能删除重要内容、

信息不足时应先核查。目标回答希望达到什么结果，约束规定哪些实现方式可以接受。一个助手即使完成整理任务，也可能因未经授权转发信息而违反约束；另一个助手可能始终不越权，却什么也不做，因而没有完成目标。

目标与约束都应落实到可检查的行为。回答内容是否有依据、行动是否得到授权、最终状态是否符合用户要求，是不同的观察对象。“模型表示自己理解了目标”不能替代这些证据。某些偏离可能源于能力不足、缺少信息或任务表述不清，也可能源于代理目标错误；仅凭一次失败，通常不能确定模型具有何种内部意图。

图 14.1 比较了两个都能清空收件箱的方案。若评价只看收件箱是否为空，两种方案都可能获得高分；一旦检查重要邮件是否保留、用户能否找回，便能区分实际后果。这里需要补充的是评价目标，而不只是让模型更快地完成原来的评分任务。




图 14.1 相同的表面完成状态，不同的任务后果。左侧通过删除清空收件箱，星标的重要邮件也被丢弃；右侧通过归档清空收件箱，用户仍能找回重要邮件。星标表示应保留的内容，空托盘表示被单独评分的表面结果。

14.1.2 行为偏离的表现与原因

设任务历史为 h ，行动为 a ，实际希望改善的后果用 $U(h, a)$ 表示。实践中通常不能直接获得 U ，只能观察评分、点击、偏好比较或任务完成标记，并据此构造奖励 $r(h, a)$ 。奖励是可优化的代理；两者在训练数据上相关，不保证经过强烈优化后仍然一致。

奖励投机（reward hacking）指系统获得较高奖励，却没有实现奖励原本代表的目标。一个只按“文件数量减少”评价整理效果的任务，会鼓励

删除本该保留的文件。改进需要回到目标定义，检查评价器和环境中的漏洞，而不只是更充分地优化当前奖励。

偏好还可能因人和情境而异。某人偏好简短回答，另一人需要详细解释；这类差别可以个性化。未经授权处理他人信息则可能属于共同约束，不能因为某个用户偏好便自动放宽。实际意图、个体偏好和共同约束应分别说明。

后文沿用同一个整理任务：整理旧邮件，保留标为重要的内容，并且不向未授权对象转发；具体整理方式允许按用户偏好选择。对一封既旧又重要的邮件，方案 *A* 是归档并建立索引，方案 *B* 是留在收件箱并加标记，方案 *C* 是直接删除。*A* 与 *B* 都保留了信息，但用户可能更偏好 *A* 的整理效果；*C* 违反保留要求，不能用速度优势补偿。这里可分别核查归档后的可检索性、邮件是否仍存在以及实际收件人，而不必把所有要求压成一个主观好评分数。

这种区分决定了如何收集反馈。邮件助手的一段摘要可能同时涉及信息完整性、语气、长度和隐私。如果标注者只给一个整体分数，训练者无法知道分数下降究竟是因为遗漏了会议时间，还是因为措辞不够亲切。把可核查的任务条件、允许变化的风格和禁止违反的边界分别记录，能够保留后续纠错所需的信息。对于确有价值分歧的问题，应明确适用人群与选择机制；对事实判断的分歧，则应检查证据，而不能直接把多数偏好当成事实。

代理目标的误差也会被选择过程放大。写成 $r(h, a) = U(h, a) + e(h, a)$ ，其中 e 为评价误差，即使在原始行为分布下 $E[e] = 0$ ，被选出的最大得分动作仍可能具有正的评价误差。因为选择偏爱得分高的动作，而得分高既可能来自真实效用，也可能来自高估。这里的条件期望已经改变，原分布上的无偏性不能直接沿用。

示例 14.1 奖励误差被优化放大 在一个教学例子中，邮件助手有三个整理方案，真实效用依次为 8, 7, 2，奖励模型给分依次为 8, 7, 9。若助手原先只考虑前两个方案，奖励看似能够正确排序；当更强的搜索把第三个方案纳入候选，最高奖励对应的真实效用反而下降。第三个方案可以是删除所有难分类邮件：它让界面整洁，却破坏了保留重要信息的要求。问题来自评价器对新方案的高估，不是搜索没有充分最大化奖励。

图 14.2 另用两条明确构造的函数表现这种可能偏离：随着代理优化增强，代理分数继续升高，实际目标先改善后变差。这不是由前述三个方案拟合的实验规律，也不表示每种代理优化都会出现同样转折。

Gao 等用一个固定的较强奖励模型提供比较标签，再训练代理奖励模




图 14.2 代理奖励持续提高而实际目标可能恶化的教学构造。令归一优化强度 $s \in [0, 1]$, 画 $r(s) = 0.2 + 0.8s$ 与 $U(s) = 0.2 + 2.8s(1 - s)$; 后者在 $s = 0.5$ 达到峰值。实线与虚线分别表示真实目标和可优化代理, 二者均为人为定义的归一量, 不是奖励模型实验或人类价值的测量结果。

型, 分别通过强化学习和从多个样本中择优来增加优化强度。他们在这一可控实验中观察到, 代理得分继续提高时, 作为参照的奖励得分可能下降。该研究使奖励过度优化可以被定量考察; 参照模型仍然是一个模型, 其得分不能等同于真实人类价值¹。

因此, 检查优化后的行为需要独立于被优化指标的证据。在邮件例子中, 可以另查应保留邮件的清单与实际操作记录, 而不是再次询问同一个奖励模型“整理得好不好”。降低优化强度、增加反馈覆盖和更新评价器能够缓解不同来源的误差; 它们都需要重新检验, 因为更精确地拟合旧分布, 并不自动补上新策略访问区域中的盲点。

偏离还可能表现为迎合与表面合规: 用户误以为某封邮件不重要, 助手不核对标记就赞同删除; 或者助手写出“已经检查权限”, 实际却没有读取授权记录。相反, 把所有整理请求都拒绝虽然能减少误删, 也会破坏应提供的服务。这些教学例子分别提示事实依据、真实执行和正常任务效用都应进入评估, 不能只检查回答是否包含合适的安全措施。

¹ L. Gao, J. Schulman, J. Hilton, *Scaling Laws for Reward Model Overoptimization* In arXiv preprint arXiv:2210.10760, 2022

14.1.3 软目标与行为边界

对于顺序决策, 记策略 π 根据历史 h_t 选择动作 a_t , r_t 为任务奖励, $c_t \geq 0$ 为风险成本, T 为时域。一个常见目标是

$$\max_{\pi} \mathbb{E}_{\pi} \sum_{t=0}^{T-1} r_t, \quad \mathbb{E}_{\pi} \sum_{t=0}^{T-1} c_t \leq b, \quad (14.1)$$

其中 b 为容许预算。该约束控制平均累计成本，不直接保证每条轨迹都安全。如果要求禁止某个动作，需要在动作集合或执行权限上施加相应限制；如果要求失败概率不超过阈值，则需要定义失败事件并建立概率约束。

将成本乘以惩罚系数并入奖励，通常便于训练，却仍需验证约束是否满足。目标表述应保持这种区别，否则“已经加入安全惩罚”很容易被误写成“不会发生违规行为”。

设一个方案的收益为 10，风险成本为 1；另一个方案的收益为 5，风险成本为 0。若优化 $r - \lambda c$ 且 $\lambda = 2$ ，前者得分 8，后者得分 5，算法会选择有风险的方案。这与目标函数完全一致。只有当风险本来就允许用收益补偿时，这种交换才符合要求；若风险代表禁止泄露的内容，允许补偿本身就写错了问题。

对长期任务，还应说明成本究竟计算什么。每步违规次数之和、至少发生一次违规的指示量、最终经济损失会给出不同约束。一次严重披露不能因随后进行了许多无害动作而被“平均掉”。第 10.2 节的风险要求在这里需要落实到轨迹、动作和受影响对象，才能进入训练与监督。

14.2 行为的评估与监督

行为评估根据要求判断一段输出或行动过程是否合适；行为监督把这种判断用于持续检查、提供反馈或发出告警。离线评价、训练反馈和在线监测可以共享判据，但用途不同：评价形成证据，反馈供后续训练使用，监测提示当前风险；它们本身不等于策略参数已经改变，也不等于动作已经被停止。具体改变行为的措施在第 14.4 节介绍。

评估与监督需要共同解决三个问题：哪些性质需要判断，依据什么记录与评价者作出判断，以及判断是否准确、及时且负担可承受。仅给一个整体好评分数，会把目标达成、规则违反和表达偏好混在一起；只增加一个监控模型，也不能补上原始记录中缺失的事实。

14.2.1 行为评估与监督的维度

评估维度由已声明的目标和约束决定。对邮件助手，至少需要分别观察以下几方面，它们可在同一条轨迹上同时测量。

- 目标达成与结果质量：邮件是否完成整理，重要信息是否可检索，摘要事实是否有依据。对应任务完成率、事实核验结果与实际损失。
- 约束遵守与影响范围：是否误删重要邮件、向未授权对象转发，操作涉及多少对象。对应具体违反事件、发生频率和严重程度。
- 决策过程与信息使用：关键操作前是否获得并正确使用必要证据，工具

调用与状态记录是否支持模型的陈述。过程检查需要核对实际调用，不能只看自述。

- 不确定情况下的处置：缺少标记或授权信息时是否澄清、复核或暂停，是否在无需停止的正常任务上过度拒绝。对应风险识别、恰当转交与错误干预的比例。

这些维度应按任务、人群和关键情境展开。用户偏好的风格可以在合规候选中比较，明确禁止的动作则应单独统计，不能由其他维度的高分抵消。跨情境稳定性需要在相同维度上改变环境后重新测量，具体机制与范围在下一节讨论。

维度与方法并不是同一层分类。“是否越权”是要判断的性质，可以通过权限表、人工复核或模型评价获得证据；“人工反馈”是证据来源，可以同时评价事实、风格和操作。“结果或过程”说明标签附在哪里，“离线或在线”说明何时评价。下面按照证据如何取得、运行时如何观测和复杂判断如何扩展来组织方法，避免把这些交叉维度当成互斥技术。

14.2.2 行为评价信号的获取

判断行为是否符合要求，既可以直接核对事实与状态，也可以由人或评价模型比较候选的优劣。评价信号的构造有两个交叉维度：由谁、依据什么给出判断，以及把判断附在完整结果还是中间步骤上。人工偏好、原则指导的模型反馈可以采用不同粒度，过程反馈也不限定必须由人给出。无论怎样组合，评价器都应保留实际要求所需的事实和约束。

事实与规则支持的直接核验 对于有明确真值或状态的任务，优先使用可复核证据。邮件保留要求可以比较操作前后的记录与索引，授权要求可以核对动作对象和收件人，摘要事实可以逐项对照原文。规则检查器给出是否满足条件及违反位置，任务测试给出完成与损失情况；它们比笼统好评分数更容易定位错误，但结论仍受规则是否完整、状态记录是否可信的限制。

人工比较与偏好评价 当人难以给出精确奖励，却能够比较两个回答时，可以使用偏好数据。设上下文为 $\mathbf{x}$ ，被偏好的回答为 y^+ ，另一回答为 y^- ，奖励模型为 r_ϕ 。一种成对偏好模型令

$$\mathbb{P}(y^+ > y^- | \mathbf{x}) = \sigma(r_\phi(\mathbf{x}, y^+) - r_\phi(\mathbf{x}, y^-)),$$

其中 $\sigma(u) = 1/(1 + e^{-u})$ 。对观察到的比较最小化负对数似然，就能够训练奖励模型。这个模型解释偏好差异的概率，仍依赖比较者、提示方式和数据分布。

偏好数据的基本记录是同一上下文、两个候选以及比较结果，而不是只收集被喜欢的回答。可以让当前策略对同一任务生成 A 、 B ，随机交换展示顺序，再记录比较者身份、选择与依据。奖励网络分别读取上下文和候选，输出两个标量；损失只通过它们的差调整参数。训练完成后，奖励模型可以给新候选评分，但这些分数还没有改变负责生成候选的策略。

在一个教学数据集中，假设针对同一对可行方案收集四次判断，其中三次偏好 A ，一次偏好 B 。若只拟合这一对，令 p 为偏好 A 的模型概率，平均损失为 $-\frac{3}{4} \log p - \frac{1}{4} \log(1-p)$ ，其最小值在 $p = 3/4$ 取得，对应奖励差 $\log 3$ 。这说明奖励差表达比较频率的相对强度。删除重要邮件的 C 应另外记录为违反约束，不能因为少数比较者喜欢“清空得快”，便把它与 A 、 B 的整理风格差异等同处理。

这一形式通常称为 Bradley-Terry 偏好模型。对同一上下文中的所有回答加上同一个常数，比较概率不变，因此仅凭成对比较无法识别奖励的绝对零点。模型还假设回答能够由一个标量分数排序。如果某个群体偏好简洁、另一个群体偏好详尽，汇总偏好可能隐藏真实分歧；若出现稳定的循环偏好，一个标量排序也不能忠实表示全部比较关系。

上述 $3/4$ 是拟合比较行为得到的概率，不是回答真实、无害或满足全部约束的概率。把奖励分数直接当作安全置信度，会混淆本章的偏好学习与第 11.2 节讨论的概率检验。

原则指导的模型评价 人工逐条比较的成本，会限制反馈能覆盖多少情况。另一个方向是由人明确原则，再让模型依据原则批评和比较回答。**宪法式人工智能** (Constitutional AI) 中的“宪法”指一组指导行为评价的书面原则，并不表示这些原则自动成为法律或取得普遍共识。Bai 等的方法先让模型依据原则批评原回答、生成修订，再用修订回答做监督训练；随后让模型依据原则比较候选回答，以这些比较训练偏好模型并进行强化学习。这一阶段通常称为 AI 反馈强化学习，即 RLAI²。

构造这类反馈时，可以向评价模型同时提供任务、候选、相关事实和适用原则，让它指出具体冲突，再生成修订或比较标签。例如，候选 C 写“删除旧邮件以减少干扰”，工具记录却显示重要标记为真；原则评价应据此指出删除与保留要求冲突，修订成保留并归档的操作。修订输出可以进入示范数据，两个候选的比较结果可以进入偏好数据。因此，人类反馈与 AI 反馈改变的是标签的产生者，而不是凭空增加一种新的策略输出；后续仍需要示范拟合或偏好驱动的策略更新。

这里自动化的是大量具体评价，而原则选择、原则冲突的处理和效果验证仍需要人负责。例如，“积极完成用户请求”与“不得披露未经授权的信息”在某个请求上发生冲突时，评价器需要知道哪一条构成不可放宽的边界。仅增加原则数量可能带来矛盾；只要求给出批评文字，也可能让模

² Y. Bai, S. Kadavath, S. Kundu, A. Aspell, J. Kernion, A. Jones, A. Chen, A. Goldie, A. Mirhoseini, C. McKinnon, C. Chen, C. Olsson, C. Olah, D. Hernandez, D. Drain, D. Ganguli, D. Li, E. Tran-Johnson, E. Perez, J. Kerr, J. Mueller, J. Ladish, J. Landau, K. Ndousse, K. Lukosuite, L. Lovitt, M. Sellitto, N. Elhage, N. Schiefer, N. Mercado, N. DasSarma, R. Lasenby, R. Larson, S. Ringer, S. Johnston, S. Kravec, S. El Showk, S. Fort, T. Lanham, T. Telleen-Lawton, T. Conerly, T. Henighan, T. Hume, S. R. Bowman, Z. Hatfield-Dodds, B. Mann, D. Amodei, N. Joseph, S. McCandlish, T. Brown, J. Kaplan, *Constitutional AI: Harmlessness from AI Feedback* In arXiv preprint arXiv:2212.08073, 2022

型学会写出合适的批评却保留原错误。

反馈来源改变后，验证对象也应改变。人工偏好需要考察标注群体和一致性，模型偏好需要另外考察评价模型与生成模型的共同盲点。应抽样检查原则是否落实到具体事实、正常请求是否被过度拒绝，以及换用评价模型或表达方式后结论是否保持。AI 反馈可以扩大训练规模，却不会把评价器的判断自动转化为独立真值。

结果评价与过程评价 无论反馈由人还是模型给出，长任务只评价最终结果时，都很难判断哪一步造成失败。过程反馈对中间操作、证据检查或计划选择提供评价，可以帮助定位问题；但局部步骤都看似合理，仍可能组合成失败结果。因此，过程反馈应与结果验证结合。

结果监督 (outcome supervision) 只给最终产物评分，**过程监督** (process supervision) 则在中间步骤提供对错或质量判断。若一道题最终答错，结果标签不能直接区分是哪一步算错；若最终碰巧答对，错误推导还可能得到奖励。过程标签提供更细的责任定位，但标注者需要理解局部步骤，标注数量也会增加。

Lightman 等在数学解题中比较这两种监督，用人对推导步骤的反馈训练过程奖励模型，并在多个候选解法中选择。研究在所用数学任务和生成设置中发现过程监督优于其结果监督基线，也研究了主动选择有价值步骤进行标注。其证据支持逐步反馈在可核查推理任务中的价值；它没有证明自然语言步骤始终忠实反映内部计算，也没有直接给出开放环境智能体的安全保证³。

可以用邮件整理说明这种差别。结果监督检查“重要邮件是否仍然存在”；过程监督还检查“删除前是否核对用户标记”“转发前是否核对收件人”。前者能发现最终损失，后者更容易定位缺失的核验操作。若模型只在日志中写“已核对”而实际上未读取标记，过程文字得分仍会误导训练。因此，能够观测的工具返回与状态变化，应成为过程反馈的证据。

过程评价的训练记录则应包含当前历史、待评步骤和局部标签。对于“读取重要标记—选择归档—检查可检索性”的序列，评价者可以给实际读取并正确使用标记的步骤正标签，给未经读取便声称“不是重要邮件”的步骤负标签。过程奖励模型读取每个前缀与当前步骤，预测该步骤的标签或质量分数；结果奖励模型可以读取完整候选，但只从最终成败得到标签。根本差别在标签约束的是当前步骤还是整项任务，而不在评价器能否看到推理文字。比较它们时，可以让两个评价器对同一批候选轨迹排序，再用独立状态检查判断各自选中的轨迹是否真正保留了邮件。

过程奖励也需要明确聚合方式。若各步分数 q_t 代表在前面步骤均正确的条件下当前步骤正确的概率，链式法则给出整条过程正确概率为 $\prod_t q_t$ ，这里不要求各步独立。但实际奖励模型输出未必具有这种条件概率含义，

³ H. Lightman, V. Kosaraju, Y. Burda, H. Edwards, B. Baker, T. Lee, J. Leike, J. Schulman, I. Sutskever, K. Cobbe, *Let's Verify Step by Step* In arXiv preprint arXiv:2305.20050, 2023

直接把任意步骤分数相乘会制造虚假的概率解释。采用最小值、平均值或加权求和时，也分别强调最差步骤、平均质量或特定步骤，需要用任务级结果检验选择是否合理。

14.2.3 运行行为的观测与监测

监督需要决定看什么。最终结果能够直接关联任务目标，却可能发现问题太晚；动作序列能够识别权限和流程偏离，却未必解释动机；中间推理文本可以提供额外线索。若把这些文本用作行为原因的解釋，需要检验它们是否真实反映了形成行为的依据；后文第 15.4 节将系统讨论这种忠实性要求。若只把文本用于告警，则应直接检验它能否帮助发现偏离，不能由语言是否流畅推断监督效果。

设监控器根据可见记录 $v(h_t)$ 输出风险分数 $m(v(h_t))$ 。记录选择决定它能够识别什么：如果关键工具参数未进入日志，监控器不能仅凭最终摘要判断是否越权。增加记录也会带来隐私与成本，需要依据风险确定必要观察。

构造监控器需要把记录与偏离事件对应起来。对于可直接核查的规则，可以读取动作名称、邮件标记及收件人授权表，输出“重要邮件被提议删除”或“目标收件人未授权”的布尔标记。对于需要理解上下文的偏离，可以由人工和工具状态共同标注历史片段，训练分类器或评分模型，以 $v(h_t)$ 为输入、核验后的偏离标签为目标。前者把已知条件写成判定规则，后者从带标签记录中拟合判定关系；两者都只产生告警或风险分数。

邮件助手若只输出“已安全归档”，监控器无法核对 C 是否偷偷被执行。若记录包含调用前的重要标记、拟执行动作和工具返回，就能在删除发生前标记冲突，并在执行后核查邮件是否仍在。这说明增加记录改变的是可识别的信息，而不是自动提升判断准确率；还需要在相同轨迹上比较不同记录范围的漏报与误报。

即使日志完整，评价者也未必能够判断行为是否正确。增加可见信息解决的是观察缺失，分解任务、查询证据和辅助判断解决的是监督能力不足，需要分别检查。

14.2.4 复杂任务中的监督能力

当执行模型在某些任务上比评价者更强，要求它完全模仿评价者，可能反而压低已有能力。**可扩展监督**（scalable oversight）研究如何借助分解、辅助工具或学习方法，使有限的监督能力覆盖更复杂行为。其困难是监督者既要利用模型完成自己难以独立完成的任务，又不能把模型自己的判断直接当作最终依据。

一种可检验的简化，是用较弱模型产生标签，再训练一个已经具有较强

预训练能力的模型。Burns 等把这一问题称为**弱到强泛化**（weak-to-strong generalization）：较强学生是否能够从较弱监督中恢复超过监督者的任务表现。研究在自然语言、棋题和奖励建模等设置中观察到这种现象，同时发现简单拟合弱标签并不能完全恢复强模型能力；辅助置信损失在部分自然语言任务中减少了对弱监督错误的模仿，但效果依赖设置⁴。

这里借助训练实验检验弱反馈能否引出更强的判断能力，尚未直接验证某个运行时监控器。把这种结果用于行为监督，还需要另行测量它对偏离事件的检出表现。这个问题与从零学习不同。强模型已经通过预训练获得可利用的表示和规律，弱标签起到指出当前任务方向的作用。如果弱标签的错误特别容易被学生学会，优化仍可能把已有正确判断覆盖掉。因而“学生超过老师”的结果不能解释为错误标签凭空提供了更多真值，也不能保证面对任何能力差距都有效。

为比较恢复程度，设同一测试分布上弱监督者得分为 s_w ，弱监督训练后的强学生得分为 s_{ws} ，用可信标签训练强模型的参照得分为 s_s ，且 $s_s > s_w$ ，则可计算

$$g = \frac{s_{ws} - s_w}{s_s - s_w}. \quad (14.2)$$

$g = 0$ 表示没有超过弱监督者， $g = 1$ 表示达到该强监督参照。它也可能小于 0 或大于 1，参照得分并非数学上的能力上限。这种指标帮助区分“有所改进”和“恢复了多少可测能力”，却仍依赖测试真值。如果真实使用场景连验证标签都无法获得，实验中的恢复率不能被直接测量。

实际比较应把弱标签生成与最终验收分开：弱模型只为训练样本提供标签，强学生据此训练；测试样本则保留可信标签，同时评价弱模型、强学生以及强监督参照。例如，在一个构造的同分布测试中，三者得分依次为 0.6、0.75 和 0.9，则 $g = 0.5$ ，表示恢复了一半的参照差距。若把用于拟合弱标签的数据直接拿来计算恢复率，就无法判断学生是否只记住了弱监督错误。将这种方法用于监控时，测试标签还必须对应真实偏离事件，而不能只对应一般问答正确率。

任务分解提供了另一种扩大监督范围的机会。审核长篇邮件报告时，可以分别核查每条事实的原始出处、归纳是否遗漏关键条件、行动建议是否超出权限。分解有用的条件是局部检查能够约束整体错误。如果几个局部结论分别正确，但组合顺序错误，或关键前提根本没有被列成子任务，全部局部检查通过仍不足以证明整体有效。因此，监督设计还需要检查分解是否完整，并保留最终任务层面的验证。多个评判者若共享训练数据和推理缺口，意见一致也不等于独立证据。

⁴ C. Burns, P. Izmailov, J. H. Kirchner, B. Baker, L. Gao, L. Aschenbrenner, Y. Chen, A. Ecoffet, M. Joglekar, J. Leike, I. Sutskever, J. Wu, *Weak-to-Strong Generalization: Eliciting Strong Capabilities With Weak Supervision* In arXiv preprint arXiv:2312.09390, 2023

14.2.5 评估与监督效果的检验

评估体系需要分别检验行为判定是否准确，以及监督在运行中是否来得及发挥作用。规则检查器应使用已知状态变化的案例核对结果；偏好评价应保留未参与拟合的比较对并报告分歧；过程评价应与独立任务结果对照。判定器在旧数据上准确，不能自动说明新策略产生的行为也被覆盖。

监控器应评价漏报、误报、发现延迟和复核成本。其分数若用于阈值决策，还需要检查与实际偏离事件的关系。训练监控器的样本、选择阈值的数据与最终测试应分开，并包含真实使用中容易混淆的正常行为。

具体检验可以固定告警规则 $m(v(h_t)) \geq \tau$ ，在独立标注的测试轨迹上逐条运行。对实际偏离的轨迹，记录是否告警以及告警是否早于不可逆操作；对正常轨迹，记录是否误告警。由此得到检出率、误报率和提前发现比例，同时累积每次告警的人工用时。阈值 τ 应在验证集上按允许的复核预算选择，再冻结用于测试；不能看到测试中的漏报后反复调整阈值，却仍把原测试称为独立证据。

评价时应区分三种判定。能够在少量异常样本中发现错误，支持识别能力；在真实发生率下仍能让复核队列及时处理，支持运行可用性；在损害发生前给出告警，才支持后续干预有机会生效。若两个监控器的观察范围不同，应在相同误报或复核预算下比较检出效果；否则“检出更多”可能只是因为它把几乎所有行为都送去复核。

示例 14.2 低发生率下的告警负担 假设偏离发生率为 0.1%，监控器检出率为 95%，正常行为误报率为 1%。每 10000 次行为期望产生 9.5 次真告警、99.9 次误告警，真告警仅占约 8.7%。高检出率仍可能带来大量复核。

监督者也需要接受故障和攻击测试。模型可能生成让评判者误判的格式，第三方内容可能污染监控上下文。可信监控不是给另一个模型加上“审核员”身份就能实现的性质，而需要独立证据、权限隔离和对失效方式的检查。

解释质量与监控效果在这里相互关联，但不能合并为一个指标。模型给出的理由即使省略了重要内部因素，也可能包含预测越权的有效信号；相反，完整描述某次局部计算，也未必能预测几步后发生的信息披露。实际测试应固定允许查看的信息，比较最终回答、动作记录和推理文本在相同误报水平下的检出能力，并检查增加信息所带来的隐私与计算成本。

还应区分旁观监控与被优化的监控。当生成模型不知道监控分数时，测试主要衡量监控器对当前行为的识别能力；当该分数被作为训练奖励或重试依据时，模型输出分布会朝更容易通过监控的区域移动。原来的漏检率不再自动成立。因此，不能只用冻结的正常样本证明一个持续反馈系统可

靠。后文第 17.2.1 节将从主动攻击者利用反馈调整策略的角度，进一步讨论这种评估条件的变化。

14.3 行为泛化与约束保持的条件

在已测任务上符合要求，只说明已有条件下的表现。行为泛化关注模型面对新情境时能否继续遵守目标与约束，行为保持还包括交互变长、模型更新和系统组件变化后，原有要求是否继续成立。这里没有一种方法能够无条件保证任意未知环境中的全部行为；能够建立的结论取决于环境变化范围、可观察状态和执行机制。

本节不按训练、推理和执行位置罗列方法，而是检查已有行为能够延伸到新条件所需的四类依据：训练与反馈是否覆盖策略实际到达的状态，形式化边界能否由执行机制保持，单步风险怎样累积为任务风险，以及模型更新后原有证据是否继续适用。具体改变行为的方法放在第 14.4 节；这里说明这些方法要支持多强的保持结论，还缺哪些条件。

14.3.1 基于训练覆盖的约束迁移

经验泛化依赖训练中学到的是任务规则还是偶然表面模式。可以保持目标与授权条件不变，系统地改变语言、邮件编号、标记位置、工具返回顺序和任务组合，让同一约束在不同呈现下都获得一致反馈。也需要配对的边界案例：相似表述在授权条件不同、重要标记不同的情况下应得到不同动作。否则模型可能只学到某个词出现时一律拒绝，而没有学到规则依赖什么条件。

训练覆盖还应包含模型自己容易到达的错误状态。只检查专家完整轨迹时，模型一旦在前几步偏离，就可能进入训练与验收都没有涉及的历史。需要在隔离或受限环境中让候选策略实际运行，收集漏读标记、工具返回缺失或计划中断后的状态，再核验这些状态下的恢复行为。这里要求的是训练条件与部署访问状态之间具有可说明的联系；怎样把新状态转化为训练数据，放到第 14.4.2 节讨论。

多情境训练、错误状态反馈和边界案例可以减少已知失配，但有限覆盖不能证明未知场景全部合规。若新环境改变了工具语义或授权规则，应先更新任务定义与状态表示，不能继续把原来的正确动作标签当成不变真值。

14.3.2 基于执行机制的约束保持

对于能够形式化的行为边界，可以把约束放入不依赖模型措辞的执行机制。例如，无论用户用哪种语言要求整理邮件，执行器都根据可信授权记

录核对目标对象。这样，对新表达的保护不必完全依赖模型学过类似句子；模型可以提出错误建议，但建议无法直接扩大允许动作集合。

要说明这种保持何时成立，可以采用一个简化状态模型。记 S_{safe} 为满足规定约束的状态集合， $A(s)$ 为状态 s 下可执行的动作集合， $\mathcal{T}(s, a)$ 包含状态 s 执行动作 a 后所有被环境模型允许的后继状态。定义

$$A_{\text{safe}}(s) = \{a \in A(s) : \mathcal{T}(s, a) \subseteq S_{\text{safe}}\}. \quad (14.3)$$

若初始状态属于 S_{safe} ，每步都有可执行的安全动作，执行器只允许上述集合中的动作，且真实后继确实被 $\mathcal{T}$ 覆盖，那么由逐步归纳可知实际状态一直留在 S_{safe} 中。归纳的一步是：当前状态安全，执行器允许的动作又只能到达安全后继，因此下一状态仍安全。

安全屏蔽 (shielding) 在学习者与环境之间加入动作检查或修正机制。Alshiekh 等依据时序逻辑规范构造屏蔽器，在动作可能违反规范时进行纠正。它说明某些约束可以通过显式环境模型与执行规则保持，而不只通过奖励惩罚促使模型遵守⁵。

上述状态模型是解释不变量的教学简化。对于依赖历史的要求，状态还须包含有关历史或规范检查状态；权限、计数和外部副作用遗漏时，归纳就不能代表真实系统。新环境中的工具效果必须仍被转移关系覆盖；否则应重新验证或限制动作。安全动作集合为空时，也需要事先分析可行回退，不能假定“停止”在所有系统里都安全。该机制保证的是形式化边界，既不保证任务一定完成，也不证明模型内在目标已经对齐。具体动作校验与干预位置将在第 14.4.6 节展开。

图 14.3 把这条边界画在执行端。模型是否提出不当动作与系统是否实际执行，需要分别记录。

⁵ M. Alshiekh, R. Bloem, R. Ehlers, B. Könighofer, S. Niekum, U. Topcu, *Safe Reinforcement Learning via Shielding* In Proceedings of the AAAI Conference on Artificial Intelligence, 2018

14.3.3 基于风险预算的长程控制

长过程还会积累局部风险。设 E_t 表示第 t 步发生规定偏离，无论这些事件是否独立，都有

$$\mathbb{P}\left(\bigcup_{t=1}^T E_t\right) \leq \sum_{t=1}^T \mathbb{P}(E_t). \quad (14.4)$$

若每步只有在部署策略产生的历史下才能保持风险上界，改变策略后就要重新核查。独立性并非联合界所需条件，但局部边际概率必须针对实际行为过程成立。

因此，一个短任务中很低的失败率，不足以直接支持长任务的同一容限。若事先给定任务级容限 α ，可以选择非负步骤预算 α_t ，要求 $\sum_{t=1}^T \alpha_t \leq \alpha$ 。若在实际策略产生的各历史下，当前步骤的条件违规概率都能由有效证据控制在 α_t 以内，则可推出相应边际概率界，再由式 (14.4) 控制任务级风险。




图 14.3 模型内的行为倾向与执行外的权限边界。训练可以改变模型提出何种动作的倾向，却不能作为硬权限的保证。A、B 示意提案引用的邮件对象，独立可信记录只允许处理 A；归档 A 被提交，删除 B 被拒，B 的状态不变。执行端另行核对授权与当前状态，提案不能扩大许可集合。安全状态的保持仍依赖正文中的转移覆盖与安全动作存在等条件。

给步骤贴上预算数字本身不会建立概率保证。任务提前结束且不再产生相关后果时，可将未执行步骤的违规事件记为空事件；已经提交、尚未完成的外部操作则仍需纳入风险范围。

例如，在一个教学设定中，任务最多 100 步，任务容限为 0.01，均匀分配得到每步预算 0.0001。该数值是待达到的要求，不是从短任务测试中自动获得的结论；若继续增加步骤，就要重新分配预算或缩小后续行动范围，不能把计数器清零后继续沿用原承诺。

机制上，可以在任务状态中保存已用次数、累计开销和剩余风险预算，在关键动作前重新检查前提，并在无法满足下一步要求时转入有明确安全条件的备用方案。缩短无效循环与减少不必要动作能够减少暴露机会，但新路线也要验证；原地停止只有在停止本身不会引发所讨论损害时才可作为安全回退。

长过程检验应保留完整任务轨迹，在不同长度和工具组合下统计至少一次违规的比例、完成任务前的中止比例和总损失。若仅保留成功完成的轨迹，就会把提前失败从统计中删掉。关键节点复核可以作为干预方案，但它是否降低整体风险，需要在同样任务与预算下比较复核前后的轨迹结果。

14.3.4 持续更新中的行为保持

若同类问题不断出现，可以将经过核验的监督结果转化为训练反馈，修正奖励或补充边界示范。但监控器的判断并非无误标签，直接回灌可能强化

误报和过度拒答。应对样本进行复核，并保留未参与更新的评价任务。

行为保持可以分别依赖旧任务数据、参考行为或参数限制，但每一种依据都可能保留原模型的错误。回放集合若只包含拒答样本，会鼓励过度拒绝；参考模型若本来存在错误，约束输出接近它也会保留错误；参数变化较小同样不能推出关键决策保持不变。具体更新方法归入第 14.4.2 节，这里只保留结论条件：更新后必须在正常任务、易混淆的合法请求和关键违规边界上重新验证。

每次干预还可能改变用户行为和未来输入。例如，大量拒答会使用户改写请求，改变监控器最初面对的分布。因此，更新的不只是模型参数，也可能是未来面对的输入分布；原先的监控阈值不能未经验证便继续沿用。

微调、模型合并、量化和持续学习都可能改变行为。参数变化小不必然意味着关键决策不变，平均能力保持也不排除少数安全场景退化。每次更新应比较原有任务、新任务、关键约束和监控器表现，并以未参与调整的数据复核。

保持对齐还需要同时评价过度拒答。若模型通过回避全部困难任务减少违规，它可能失去原本需要的服务能力。可以把合法任务完成、错误干预和约束违反分别报告，避免一个综合分数掩盖行为变化。

监督和干预也会失配：新模型或推理格式可能使旧监控器失效。因此，更新验证需要覆盖观察信息、阈值、工具权限和重试规则。

14.3.5 泛化与保持效果的检验

模型在熟悉提示上表现合适，不意味着新语言、组合任务或更长行动链中仍遵守同样要求。评价应区分任务难度增加造成的能力失败，与知道目标却优化了错误代理造成的目标偏离；二者可能产生相似结果，却需要不同修正。可以对同一任务构造目标说明更明确、所需知识有证据支持的对照条件，观察偏离是否减少，再分别改变语言、角色与工具条件。这样的对照有助于定位缺口，但行为失败本身通常不能唯一识别内部目标，模型声称“知道要求”也不能代替证据。

只改变任务难度还不足以覆盖情境变化。另一种更难发现的形式是：模型在通常测试条件下遵守要求，却在特定条件出现时改变行为。Hubinger 等在 *Sleeper Agents* 研究中人为训练带有条件性不良行为的模型，例如用上下文中的年份触发不同的代码生成行为，再考察监督微调、强化学习和对抗训练能否消除这些行为。若干设置下，条件性行为在安全训练后仍然存在；这是人为构造的概念验证，不能据此推断普通部署模型自然形成同类策略的发生率⁶。

这种在特定条件出现时激活异常行为的机制，也可能被攻击者有意植入模型；后文第 17.1 节将从攻击者植入条件触发行为的角度讨论这种风险。

⁶ E. Hubinger, C. Denison, J. Mu, M. Lambert, M. Tong, M. MacDiarmid, T. Lanham, D. M. Ziegler, T. Maxwell, N. Cheng, A. Jermyn, A. Askill, A. Radhakrishnan, C. Anil, D. Duvenaud, D. Ganguli, F. Barez, J. Clark, K. Ndousse, K. Sachan, M. Sellitto, M. Sharma, N. DasSarma, R. Grosse, S. Kravec, Y. Bai, Z. Witten, M. Favaro, J. Brauner, H. Karnofsky, P. Chris-

本章关心的是由此暴露的验证缺口。若评价只覆盖没有触发条件的输入，训练前后都可能得到良好分数，进而把“未激活”误认为“已消除”。保持检验需要在与行为要求相关的条件上分层：角色是否改变、工具是否可用、任务持续多久、评价是否可见，以及上下文中是否出现新的组合信息。

测试情境应尽量保留真实任务所需的行动机会。若被测模型没有工具权限，无法出现越权调用，并不说明有权限时也会主动守住边界。反过来，为了测试某种偏离而额外告知模型“当前可以违规”，又可能人为改变了原任务。有效压力测试需要记录这些差别，将构造条件下的失败与真实分布中的频率分别报告。

构造迁移测试时，可以从同一封邮件派生成对任务：仅改变请求语言、仅改变重要标记的位置、或仅增加一个会返回额外信息的工具。保持正确动作与保留约束不变，比较原条件和新条件下的任务完成、违规及监控漏报。如果某组失败增加，再检查提供缺失事实后是否恢复、执行边界是否仍有效。这样的逐因素对照有助于定位失效条件；真实部署还要覆盖因素共同变化的组合，并按实际任务分布估计总体风险。

更新后的测试也应覆盖已有纠错是否仍然有效。以邮件助手为例，可以把过去核验过的正常任务、易混淆但合法的任务和曾造成损失的任务保留为回归集合，同时补充未见过的新表达。只反复使用固定题目会逐渐把评估变成训练的一部分，因此回归集合用于发现已知退化，独立留出与新的压力测试用于发现未知退化，两者回答不同问题。

更新验收可以把旧版和新版放在相同任务、工具返回与随机条件下成对运行，分别记录双方都成功、仅旧版成功、仅新版成功和双方都失败的任务。只有新版成功的任务反映收益，只有旧版成功的任务暴露遗忘或新失效；平均成功率相同可能同时隐藏这两类变化。对关键约束还应单独检查新增违规，并让旧监控器在新版轨迹上重新评价。若需要重选阈值，应另留最终测试数据，待整个“新版策略—新版阈值—执行规则”固定后再作验收。

泛化结论应说明证据的性质。跨情境训练通过留出环境上的结果支持经验迁移；执行不变量依靠状态、转移和权限假设给出条件保证；长程预算依赖局部风险界；更新保持通过回放或正则化减少遗忘，再由独立测试核验。某个机制没有覆盖的新工具、状态或人群，应保留为未验证范围，不能由其他条件下的平均分数补足。

14.4 行为干预

行为干预是在目标、约束或监督证据的指导下，改变模型将采取的行为或限制其后果。它既包括部署前修正学习过程，也包括运行中的即时纠偏。前节解释保持机制为何可能延伸到新条件；本节进一步区分何时介入、改

变哪个对象，以及改变后怎样验证。

下面先讨论干预时机与选择依据，再按作用位置介绍五类操作：训练阶段的数据与参数修改、推理前的输入与上下文调整、推理中的内部计算调整、生成后的候选筛选，以及行动执行与损害恢复。训练、上下文和内部计算干预改变候选如何产生，结果筛选改变哪些候选被交付，执行端决定哪些动作真正发生；它们可以组合，最终仍需按完整行为过程验收。

14.4.1 干预时机与方案选择

干预不必等到违规已经发生：部署前可修正反复出现的行为偏差，运行时可在证据不足、监控告警或动作触及边界时介入，事后则处理已经产生的状态变化。反复出现的系统性问题适合反馈到训练，一次请求中的信息缺口通常先在该请求中处理。

低风险的不确定情况可以请求澄清或补充信息；可纠正的输出可以重新生成；涉及权限边界的动作应由执行端限制；高损失且不可逆的行动可能需要人工接管或停止。

一个简化的决策可以说明阈值为何依赖后果。假设继续执行造成损害的概率为 $p(h)$ ，损害成本为 c_{harm} ，停止成本为 c_{stop} ，且停止能够完全避免所讨论的损害，则当 $p(h)c_{\text{harm}} > c_{\text{stop}}$ 时，停止的期望损失较小。若干预不能完全避免损害，或不同动作具有不同代价，就需要重新计算。这一规则依赖风险估计有依据，不能直接把任意监控分数当成概率。

例如，在一个教学设定中，误删重要邮件的损失为 100，暂停等待复核的成本为 2，那么停止阈值为 $p(h) > 0.02$ 。风险估计为 0.03 时，继续的期望损失为 3，暂停更合适；风险估计为 0.005 时，继续的期望损失为 0.5，单按这项损失比较则无需暂停。若动作违反的是明确授权边界，应直接由执行规则拒绝，而不是因估计概率低于阈值就放行。概率阈值用于比较允许决策中的不确定后果，授权规则用于排除根本不允许的动作。

人工接管也需要可执行条件：人应得到必要上下文，有时间作出判断，并具有停止或纠正的权限。只增加一个确认按钮，而没有改善信息和责任边界，可能只是把同样的错误交给人重复。

14.4.2 训练阶段的数据与参数干预

这类干预在部署前或版本更新时修改训练数据、评价目标与策略参数，作用会持续到后续任务。若偏离来自缺少正确示范，可以补充具体行为；若来自代理评价遗漏，应先修正反馈或约束，再优化策略。只在错误目标上继续训练，会放大第一节讨论的代理偏差。

示范给出可模仿的路径，评价信号区分候选优劣，参数更新使某些路径更常出现。反馈的来源与粒度见第 14.2.2 节；这里关注怎样将反馈变成生

成行为的变化。训练介入应保留原版本与独立验收集，以便区分改进和附带退化。

通过示范修正行为 示范数据提供在具体历史下希望采取的行为。**监督微调**（supervised fine-tuning, SFT）使模型增加示范输出的概率，能够传递格式、任务程序和部分约束。但学习到的是数据覆盖下的行为模式，示范没有涉及的边界仍需检验。

若回答 y 由词元 $y_1, \dots, y_m$ 组成，示范微调最小化

$$L_{\text{SFT}}(\theta) = -\mathbb{E}_{(\mathbf{x}, y) \sim D_{\text{demo}}} \sum_{t=1}^m \log \pi_{\theta}(y_t \mid \mathbf{x}, y_{<t}), \quad (14.5)$$

其中 D_{demo} 是示范分布， $\mathbf{x}$ 是任务上下文， π_{θ} 是参数为 θ 的生成策略， $y_{<t}$ 为前面的词元。训练把示范中的前缀作为条件，部署时却接着模型自己的前缀继续生成。一个早期错误可能把后续生成带入示范未覆盖的状态，这解释了为什么学会模仿标准答案，还需要在完整交互上检验。

这类训练具体需要成对记录“模型当时看到了什么”和“希望它接下来输出什么”。在邮件任务中，输入可以包含用户要求和当前可见的邮件信息，示范则依次读取重要标记、调用归档工具、确认邮件仍可检索。若模型通过文本调用工具，调用名称与参数也属于要学习的输出；工具返回作为后续动作的上下文，不应被当成模型可以任意编造的答案。式 (14.5) 降低示范序列的负对数概率，使策略更容易产生这条路径。

示范的产物是生成策略，而不是给任意候选打分的评价器。一条正确的 A 方案示范并没有直接告诉模型 A 比 B 好多少，也没有穷举所有不允许的 C 方案。要检查学到的是程序还是表面措辞，可以保留要求而改变邮件编号、标记位置和工具返回，再让模型自己完成整段交互，检查关键动作及最终状态。

只模仿专家产生的完整轨迹，还可能遗漏模型自行运行时进入的错误状态。数据集聚合（Dataset Aggregation, DAgger）反复运行当前策略，请专家为策略实际到达的状态提供动作标签，再把这些状态加入训练数据。Ross 等在相应在线学习假设下分析了这种方法；它减少的是训练状态与策略访问状态之间的失配，不是对任意新环境的安全承诺⁷。在邮件任务中，可以在隔离环境中收集漏读标记或工具返回缺失后的历史，再为恢复读取、澄清或停止操作提供示范，避免先在真实用户数据上执行危险动作。

通过评价反馈调整策略 获得评价之后，还需要让生成策略改变选择。显式训练奖励模型并用它优化策略，与直接从成对偏好调整策略，是连接相对评价和行为概率的两条路线。两者共享前面的评价误差与覆盖限制；是

⁷ S. Ross, G. Gordon, D. Bagnell, *A Reduction of Imitation Learning and Structured Prediction to No-Regret Online Learning* In Proceedings of the Fourteenth International Conference on Artificial Intelligence and Statistics, 2011, pp. 627–635

否单独保留奖励模型，不会改变反馈本身的真伪。

人类反馈强化学习（reinforcement learning from human feedback, RLHF）的一条常见路线，是把“人能比较少量行为”转化为“奖励模型能给大量新行为评分”，再用该奖励优化策略。Christiano 等工作比较行为片段，以学习到的偏好预测作为强化学习奖励，连接了人的判断与策略优化。比较反馈可以比直接示范更容易获得，但标签分歧、遗漏因素和奖励模型外推都会进入最终行为，偏好拟合不等于完整的使用安全保证⁸。

。

实际学习形成循环：当前策略产生候选行为，人比较其中一部分，奖励模型更新后再指导策略。继续收集新策略产生的数据，可以减少只依赖初始行为样本的局限，但也增加反馈成本。

在一次策略更新中，先固定奖励模型，从当前策略采样完整回答或行动轨迹，并计算每个样本的奖励。更新再利用“该样本的得分比当前通常水平高多少”来调整它的生成概率：高于基准的样本获得增加概率的信号，低于基准的样本获得相反信号。奖励模型提供训练信号，策略参数承担行为改变；若更新的是奖励模型而策略不动，生成行为不会因此自动改善。后续重新采样可以看到这种概率变化实际带来了哪些新候选。

InstructGPT 将这一路线用于指令跟随：用人工示范得到初始策略，收集回答排序训练奖励模型，再使用近端策略优化调整生成策略，同时约束它偏离参考模型的程度。论文还混入预训练数据上的语言建模目标，以缓解部分任务能力退化。其贡献是展示通用语言模型能够通过这种反馈流程更符合特定标注群体对指令回答的要求；这并不代表所有人群的价值已被统一，模型仍会出现事实错误和其他失败⁹。

在这里，强化学习所需要的背景可以压缩到一个关系：模型采样出回答，奖励模型评价回答，策略更新提高较高奖励回答出现的概率。近端策略优化通过限制相对于采样策略的概率比变化，减轻单次更新过大的问题。这种优化稳定性与行为可靠性属于不同判断：即使每一步更新都很平稳，反复优化一个有偏奖励，仍会逐渐得到不符合实际意图的行为。

若只追求奖励模型得分，策略可能走向奖励模型没有可靠数据支持的输出。可以以参考策略 π_{ref} 为基准，对偏离施加 KL 散度惩罚。固定上下文 $\mathbf{x}$ ，理想化目标为

$$\max_{\pi} \mathbb{E}_{y \sim \pi} [r(\mathbf{x}, y)] - \beta D_{\text{KL}}(\pi \| \pi_{\text{ref}}), \quad \beta > 0. \quad (14.6)$$

第一项提高奖励，第二项限制策略远离参考分布。较大的 β 通常使更新更保守，但参考策略本身可能包含错误，KL 约束也没有规定哪些行为绝对禁止。它控制的是相对于参考策略的概率变化，不是行为安全性的直接保证。

⁸ P. F. Christiano, J. Leike, T. B. Brown, M. Martic, S. Legg, D. Amodei, *Deep Reinforcement Learning from Human Preferences* In Advances in Neural Information Processing Systems 30, 2017, pp. 4299–4307

⁹ L. Ouyang, J. Wu, X. Jiang, D. Almeida, C. L. Wainwright, P. Mishkin, C. Zhang, S. Agarwal, K. Slama, A. Ray, J. Schulman, J. Hilton, F. Kelton, L. Miller, M. Simens, A. Askell, P. Welinder, P. Christiano, J. Leike, R. Lowe, *Training Language Models to Follow Instructions with Human Feedback* In arXiv preprint arXiv:2203.02155, 2022

直接偏好优化（direct preference optimization, DPO）利用上述正则化目标所对应的奖励与策略关系，直接从成对偏好调整策略。记

$$d_{\theta}(\mathbf{x}, y^+, y^-) = \log \frac{\pi_{\theta}(y^+ | \mathbf{x})}{\pi_{\text{ref}}(y^+ | \mathbf{x})} - \log \frac{\pi_{\theta}(y^- | \mathbf{x})}{\pi_{\text{ref}}(y^- | \mathbf{x})},$$

则训练目标是偏好样本上的 $-\log \sigma(\beta d_{\theta})$ 的平均。它避免显式训练并调用一个独立奖励模型，但仍依赖偏好数据和所采用的模型关系¹⁰。

若 d_{θ} 较小，损失会推动当前策略相对于参考策略更偏向优选回答。DPO 省去的是独立奖励模型与在线奖励调用，不是比较信息，也没有消除偏好噪声、分布覆盖和过度优化。离线偏好若只覆盖旧策略输出，新策略转向的区域仍可能缺少可靠评价；参数 β 和参考策略共同控制学习尺度，不能仅凭训练目标下降便推断行为更加安全。

版本持续更新时，还要显式保留旧任务和关键边界。数据回放让旧案例继续产生训练信号，输出约束要求新模型在保留任务上接近经过核验的参考行为，参数约束则限制被认为重要的权重变化。弹性权重巩固（elastic weight consolidation, EWC）根据旧任务估计参数重要性，在新任务训练中更强地惩罚重要参数偏离旧值；它能够缓解相应任务上的遗忘，却不能把旧任务重要参数直接等同于全部行为约束¹¹。三类方法分别保留经验、行为或参数，更新后仍需按第 14.3.4 节重新验证正常任务、合法边界案例和关键违规情形。

14.4.3 推理输入与上下文的干预

若当前偏离源于信息缺失或任务含糊，可以在模型作出决定前改变它获得的上下文，而无需立即更新参数。具体操作包括请求用户澄清冲突要求、检索可核查证据、刷新已过时的工具状态，以及把相关授权范围明确传给模型。干预的位置是本次推理的条件，效果主要作用于当前请求；它不自动修复模型在其他任务中的同类偏差。

在邮件例子中，重要标记缺失时应重新读取或请求确认，而不是让模型依据语气猜测。用户要求“清理所有旧邮件”与既有保留规则冲突时，可以先说明冲突，再取得足以确定允许动作的信息。补充的内容也需要来源和访问范围：未经核验的检索片段可能增加错误，最新授权应来自独立权限记录，不能由模型自己补写一句“已获授权”。

对于长交互，可以把当前目标、已经确认的约束、已执行动作和未决问题保存在可核查状态中，避免关键信息因上下文截断而丢失。每次高影响动作前从真实工具状态刷新这些条件。摘要有助于控制长度，但摘要遗漏约束会造成新的失配，因此关键权限和不可逆动作记录不应只依赖模型自由生成的摘要。

验证这类干预时，应在同一任务上比较补充信息前后的动作和结果，并

¹⁰ R. Rafailov, A. Sharma, E. Mitchell, S. Ermon, C. D. Manning, C. Finn, *Direct Preference Optimization: Your Language Model is Secretly a Reward Model* In arXiv preprint arXiv:2305.18290, 2023

¹¹ J. Kirkpatrick, R. Pascanu, N. Rabbinowitz, J. Veness, G. Desjardins, A. A. Rusu, K. Milan, J. Quan, T. Ramalho, A. Grabska-Barwinska, D. Hassabis, C. Clopath, D. Kumaran, R. Hadsell, *Overcoming Catastrophic Forgetting in Neural Networks* In Proceedings of the National Academy of Sciences, 2017

检查模型是否实际使用了新增证据。仅把提示写得更长，或者回答中重复约束，不足以确认行为已经改变。若缺口仍无法补齐，应进入澄清、受限执行或人工接管，而不是继续以高置信措辞掩盖信息不足。

14.4.4 推理计算过程的干预

输入干预改变模型所见的条件，内部计算干预则直接修改生成过程中的表示；后面介绍的输出筛选是在候选已经生成后再决定是否交付。设某层的激活为 $\mathbf{z}$ ，通过标注样本找出与目标属性相关的方向 $\mathbf{v}$ ，一种简化的控制形式是 $\mathbf{z}' = \mathbf{z} + \alpha \mathbf{v}$ ，其中 α 决定干预强度。它改变后续计算，使特定行为更容易或更难出现，而不必重新训练全部参数。

Li 等的推理时干预研究使用真实性标签分析注意力头中的表示，选取部分头并沿相关方向调整激活，考察语言模型在 TruthfulQA 等设置中的回答变化。工作展示了内部表示可以成为行为控制的操作位置，同时也报告了真实性与有用性之间的取舍。这里观察到的特定方向不能直接解释为一个跨任务通用的“诚实开关”¹²。

一般的表示干预可以按“估计方向—选定位置和强度—独立测试”构造。一个教学实现是固定层和取激活的位置，收集经核验的合规与不合规行为，计算两组激活均值之差，在差向量非零时将其归一化为方向 $\mathbf{v}$ ；也可以训练线性分类器，用其法向量作为候选方向。随后固定模型参数，在验证集上尝试少量干预强度 α ，同时测量违规与任务完成，选择满足预设要求的强度后冻结，在新任务上评价。这里说明的是一类方向构造方法，并非前述论文的完整实现。

在邮件任务中，方向标签如果只是区分“回答含有安全字样”与“不含”，得到的很可能是措辞方向。更合适的标签应来自重要邮件是否实际保留、动作是否授权等结果，并控制任务难度和输出长度。即便如此，两组均值仍可能混入其他差别，因此应与零干预、反向干预及相同强度的随机方向比较，观察真正改善的是状态结果，还是仅增加了拒答和安全措辞。

后文第 15.3.2 节将把类似的内部计算干预用于解释，其目标与这里不同：解释需要说明某个表示怎样参与原来的计算，干预需要确认改变表示后行为是否更符合需求。一个方向能够预测标签，只说明相关；干预后得分提高，则还需排除缩短回答、增加拒答等替代原因。有效验证应同时保留任务完成度，改变测试领域、提示方式和干预强度，检查效果是否只依赖局部样本。

14.4.5 生成结果的筛选与修订

当目标是改变交付给用户的内容，而候选生成本身没有外部副作用时，可以先生成再筛选：拒绝某个候选、要求修订，或从多个候选中选择。这里

¹² K. Li, O. Patel, F. Viégas, H. Pfister, M. Wattenberg, *Inference-Time Intervention: Eliciting Truthful Answers from a Language Model* In arXiv preprint arXiv:2306.03341, 2023

改变的是交付规则，不必更新策略参数，也不等同于保证工具动作获得了授权。

筛选器的输入是一组尚未执行的候选及其可见证据，输出是一个被选候选或“无候选可交付”。在邮件例子中，可以先产生 A 、 B 、 C 三份计划，按保留要求排除 C ，再在 A 与 B 之间比较整理效果；如果没有候选通过约束检查，就转入澄清或人工复核，而非强行选得分最高者。排序得分与约束标记在这里用途不同，必须先定义“可交付”，再讨论可交付集合中选哪一个。候选文本通过检查后，实际工具调用仍需经过执行端授权。

干预后的新输出仍需检查。反复采样直到监控器放行，可能只是找到监控器漏检的回答。若选择规则改变了输出分布，原有可靠性和安全评价需要随之更新。重试次数、筛选规则及失败后的处理，都属于被评价的系统。

从多个候选中选择最高分回答，是一种无需更新模型参数的干预，常称为 $\text{best-of-}n$ 选择。它将生成能力与评价能力分开：基础模型提供候选，评价器决定实际交付什么。若候选中已有优质答案且评价器能正确排序，增加候选可以改善结果；若高分区恰好有系统性误判，增加候选也会更容易找到这种误判。因而采样预算与评价器必须一起验证，不能把基础模型的单次生成结果当成整个选择系统的表现。

对只作二元放行的过滤器，可以直接算出被放行样本的风险。设基础分布中违规比例为 ρ ，违规样本通过过滤的概率为 u ，正常样本通过的概率为 v ，且分母为正，则

$$\mathbb{P}(\text{违规} \mid \text{通过}) = \frac{\rho u}{\rho u + (1 - \rho)v}. \quad (14.7)$$

若 $\rho = 0.1$ 、 $u = 0.05$ 、 $v = 0.9$ ，这一构造例子中的通过后违规比例约为 0.61%。结果同时取决于基础分布、漏检和正常请求通过率；只报告 u 会遗漏过滤器拒绝正常任务的代价。

在独立同分布重采样、固定过滤器且最终成功得到通过样本的理想设置下，反复采样得到的输出仍服从上述条件分布，不能仅因重试次数增加就断言每个交付结果风险必然上升。不过，若每次生成都可能发生未经隔离的副作用，累计损失会增加；若后续候选依据拒绝理由自适应改写，则独立同分布条件已经失效，需要单独评估。这些区别决定重试策略究竟改变了哪一种风险。

14.4.6 行动执行与损害恢复

生成层面的修改可以降低提出不当动作的概率，但外部后果最终取决于执行器是否实施该动作。因而工具授权与状态恢复需要在执行端单独落实。

式 (14.3) 已经给出保持安全状态所需的条件。落实到邮件系统时，执行器将模型提案解析成“动作、对象、参数”，再与独立授权记录比较：重

要邮件的删除请求和许可集合外的转发请求直接拒绝，合法归档则在真正提交前重新确认对象状态。模型只接收成功结果或明确的拒绝原因，不能通过生成文本修改授权记录。这里关注非恶意偏离也必须受到执行边界约束；第 17.3.4 节将进一步检查攻击者能否伪造、绕过或组合利用这些条件。

表示控制也不适合承担所有边界。它可能降低泄露概率，却不能像执行端权限检查那样直接规定某个收件人不可访问某份文件。对于不可逆操作，应让生成层的行为改善与动作层的授权相互补充，并分别给出证据。将它们放进同一个综合分数，会遮住其中一层失效后系统还剩下什么保护。

恢复措施则需要区分可逆与不可逆影响。撤销尚未执行的动作、恢复本地状态和收回已披露的信息具有不同可行性。干预机制应尽量在不可逆后果发生前生效，并报告未能阻止的残余损失。

验证执行干预时，应固定模型提出的请求，检查合法请求能否通过、越权对象或参数是否被阻断，以及阻断时是否已经产生外部副作用。验证恢复措施则要记录实际恢复的状态和仍然残留的损失。模型在文本中表示“已经撤回”不能替代状态检查；这些结果也不能用生成内容的无害率代替。

14.4.7 干预效果与代价的验证

干预是否有效，需要比较同一目标和约束下实际行为的变化。训练损失下降、风险分数降低或拒答增加，都不能单独替代任务结果与约束证据。参考策略约束也不意味着参考策略本来就安全。

检验对象应是更新后的完整行为，而不是仅比较训练损失。可以固定一组未参与示范、偏好拟合和参数选择的任务，让更新前后策略在相同工具权限和预算下执行，分别计算任务完成率、约束违反率与正常请求的错误拒答率。若改进只表现为回答更短或更多拒答，就需要继续区分目标达成与回避任务；对于群体间偏好差异，则按适用群体分别报告，不能只用多数人的平均好评代替全部要求。

奖励评价还应与独立证据对照。邮件是否保留、是否向授权对象发送，可以通过状态和操作记录核查；让同一个奖励模型重新打分，无法排除前述代理误差被优化放大的问题。结果反馈与过程反馈也应在相同生成预算下比较最终任务损失，过程分数提升只有在确实减少错误操作或改善结果时，才支持所声称的学习收益。

可以把一次验收具体化为三组观测。偏好拟合使用未训练的比较对，记录比较对数损失与排序错误；它回答评价信号是否学好。任务评价让策略在留出邮件任务上自由执行，记录归档成功、误删和未授权转发；它回答行为是否改善。约束评价另外覆盖重要标记缺失、工具返回异常等情形，

记录模型是否停止、请求澄清或继续高风险动作。三组结果不互相替代：第一组改善而第二组退化，提示评价外推或优化出了问题；第二组平均改善而第三组出现关键违规，也不能按平均收益直接扩大权限。容许错误率和最低任务完成度应在观察最终测试结果之前约定，并结合样本量与估计误差判断。

检验还应覆盖训练交互中的约束，而不能只检查最终策略。一个策略可能最终学会避开危险动作，却在训练交互中已经造成不可接受损害。可以利用仿真、离线数据、受限动作空间和安全参考策略降低探索风险，但仿真差距与离线数据覆盖仍是边界。学习方法只能在这些条件下逐步扩大行为范围。

对于参数不变的运行时干预，可以在相同任务上比较无干预、仅筛选、仅表示调整及完整组合，记录任务完成、实际违规、错误阻断、复核负担和总延迟。检查候选生成阶段是否已产生副作用，并把所有重试纳入预算；否则交付结果看似合规，过程仍可能造成损害。对于训练干预，另需在版本层面比较旧任务保持和新任务收益。

完整验证应记录告警何时出现、干预何时生效，以及不可逆操作是否已经发生。若监控器准确却因处理延迟未能及时阻止损害，问题出在响应机制；若及时阻断了正常任务，则需要检查判断阈值与授权条件。这样的分层记录把“发现偏离”和“纠正偏离”的贡献分开，同时保留组合系统的最终损失。

14.5 前沿研究

前沿研究进一步追问两个边界：模型能力和推理方式改变时，可见记录还能够提供多少监督信息；当系统主动寻找监控盲点时，监督与干预的组合是否仍然有效。

14.5.1 可见信息的监督价值

一个研究方向是直接评价**可监控性**（monitorability），即行为偏离能否从允许观察的信息中被发现。Guan 等提出干预、过程与结果性质等评价方式，并比较思维链和动作信息的监控作用。其结果说明可见过程可以提供有用信号，但监控效果随模型、任务和计算设置变化，不能据此认定思维链完整揭示了内部原因¹³。

解释忠实性要求可见理由反映模型行为，监督效果则要求这些信息帮助发现偏离，两者的区别见第 14.2 节。可监控性研究进一步需要比较监督效果如何随任务难度、可见记录和监控预算变化：若换一种推理格式就使检出率下降，原有证据便不能直接用于新的生成过程。

¹³ M. Y. Guan, M. Wang, M. Carroll, Z. Dou, A. Y. Wei, M. Williams, B. Arnav, J. Huizinga, I. D. Kivlichan, A. Glaese, J. Pachocki, B. Baker, *Monitoring Monitorability In Proceedings of the 43rd International Conference on Machine Learning*, 2026, pp. 37538–37602

14.5.2 监督与干预组合的抗规避能力

另一个方向是把监控器纳入攻击目标。Terekhov 等研究了解控制协议与监控模型的攻击者，在所测协议和基准中通过适应性输入绕过监控。这个结果提醒我们检查监督与重采样等干预的组合，而不能将监控器的可信身份当作不会失效的假设¹⁴。

这些前沿问题共同推动评价单位从单个回答转向完整的行为过程。一个模型可能在单次比较中更受偏好，却需要更多重试才能通过独立检查；一个监控器可能提高检出率，却造成关键任务延迟；一个干预规则可能减少输出违规，却把错误转移到工具调用。后续研究需要在明确任务、权限、预算和损失定义的条件下来比较整个过程，同时分别保留各层的测量结果，才能知道改进究竟来自哪里。

对齐证据的更新也需要可追溯的行为变化描述。只写“新版本更加安全”不足以支持扩大使用范围；更有用的结论应说明哪类任务的失败减少、正常任务是否受损、测试覆盖了哪些新能力，以及哪些场景仍需要人工或执行边界。新方法可以增加证据覆盖，却不能消除前面各章所强调的适用条件。

14.6 本章小结

邮件助手的目标是帮助用户整理并保留需要的信息，行为约束则规定它能操作哪些对象、何时必须核查，以及哪些后果不能用效率补偿。奖励、偏好和自然语言承诺都只是实现与观察这些要求的一部分；对齐证据必须回到真实任务、实际操作和受影响对象。

评估分别观察目标达成、约束遵守、证据使用和不確定情况下的处置。规则与状态核验、人工比较、原则指导的模型评价以及过程反馈提供不同证据；运行监测将可见记录转成告警，可扩展监督尝试弥补评价者的能力限制。评价准确、告警及时与干预有效是不同要求，必须分别验证，不能由一个好评分数替代。

新环境中的保持依赖机制和条件。训练覆盖与策略访问状态的反馈减少经验失配；执行端不变量在状态模型和权限条件成立时保持形式化边界；长程预算控制整个任务的风险范围；更新时的回放与行为、参数约束减少既有能力退化。有限测试不能保证任意未知情境，这些机制也不能自动证明模型内部目标已经符合全部要求。

干预按作用位置改变数据与参数、输入上下文、内部计算、交付结果或外部动作。选择时应区分长期学习缺口与即时信息不足，并优先在不可逆后果发生前介入。干预后，原来的输入分布、监控阈值和重试过程可能发生变化，因此需要重新核对完整行为系统的收益、违规、误拒与残余损失。前面讨论的可靠性、鲁棒性与公平性为这些判断提供了不同侧面的要

¹⁴ M. Terekhov, A. Panfilov, D. Dzenhaliou, C. Gulcehre, M. Andriushchenko, A. Prabhu, J. Geiping, *Adaptive Attacks on Trusted Monitors Subvert AI Control Protocols* In International Conference on Learning Representations, 2026

求。监督可以发现某项行为不符合要求，但未必说明模型为什么作出它；下一章将讨论解释行为的证据，区分可以观察到的关联与经过检验的内部作用。隐私和对抗安全两章则将继续限定信息使用与外部操纵的边界。

延伸阅读 Christiano 等的人类偏好学习与 Ouyang 等人的指令跟随流程，适合继续追踪“比较反馈—奖励模型—策略更新”之间的信息传递。阅读时应区分偏好拟合、策略优化和最终行为验收，不能由训练奖励提高直接推出实际目标已经实现¹⁵。。

若关注原则监督和能力差距，可结合宪法式人工智能与弱到强泛化研究。前者考察如何把书面原则转成反馈，后者检验较弱监督能否引出更强表现；两者都保留评价器覆盖与独立验收这一边界¹⁶。。

¹⁵ P. F. Christiano, J. Leike, T. B. Brown, M. Martic, S. Legg, D. Amodei, *Deep Reinforcement Learning from Human Preferences* In Advances in Neural Information Processing Systems 30, 2017, pp. 4299–4307; L. Ouyang, J. Wu, X. Jiang, D. Almeida, C. L. Wainwright, P. Mishkin, C. Zhang, S. Agarwal, K. Slama, A. Ray, J. Schulman, J. Hilton, F. Kelton, L. Miller, M. Simens, A. Askell, P. Welinder, P. Christiano, J. Leike, R. Lowe, *Training Language Models to Follow Instructions with Human Feedback* In arXiv preprint arXiv:2203.02155, 2022

¹⁶ Y. Bai, S. Kadavath, S. Kundu, A. Askell, J. Kernion, A. Jones, A. Chen, A. Goldie, A. Mirhoseini, C. McKinnon, C. Chen, C. Olsson, C. Olah, D. Hernandez, D. Drain, D. Ganguli, D. Li, E. Tran-Johnson, E. Perez, J. Kerr, J. Mueller, J. Ladish, J. Landau, K. Ndousse, K. Lukosuite, L. Lovitt, M. Sellitto, N. Elhage, N. Schiefer, N. Mercado, N. DasSarma, R. Lasenby, R. Larson, S. Ringer, S. Johnston, S. Kravec, S. El Showk, S. Fort, T. Lanham, T. Telleen-Lawton, T. Conerly, T. Henighan, T. Hume, S. R. Bowman, Z. Hatfield-Dodds, B. Mann, D. Amodei, N. Joseph, S. McCandlish, T. Brown, J. Kaplan, *Constitutional AI: Harmlessness from AI Feedback* In arXiv preprint arXiv:2212.08073, 2022; C. Burns, P. Izmailov, J. H. Kirchner, B. Baker, L. Gao, L. Aschenbrenner, Y. Chen, A. Ecoffet, M. Joglekar, J. Leike, I. Sutskever, J. Wu, *Weak-to-Strong Generalization: Eliciting Strong Capabilities With Weak Supervision* In arXiv preprint arXiv:2312.09390, 2023

可解释性

邮件被模型拦截后，用户希望知道哪些内容触发了判断；开发者则想知道模型是否依赖了不稳定的页脚；如果确实误拦，用户还需要知道如何补救。这三个问题分别涉及单次行为、整体规律和可行行动。给出一张特征热力图，并不自动同时回答它们。

在第 10 章的三层架构中，本章对可解释性的讨论主要位于证据能力层：解释为理解、质疑和补救模型行为提供依据。系统属性或规范要求层先规定需要解释哪项行为、解释应支持哪种判断；解释对谁可见、能否随模型更新继续成立，以及能否抵抗有意规避，则需要在威胁与生命周期治理层继续检查。

可解释性（interpretability）关注人能否依据适当的表示和证据理解模型行为。第 12 章通过改变模板发现了可能的捷径，但一次测试失败还不足以定位模型依赖的具体因素。前一章对模型行为作出评估并设置约束，这里进一步追问模型依据什么产生行为，以及哪些证据能够支持这种判断。本章由此确定解释目的，再分别讨论整体与单次行为。解释的质量需要在使用前得到检查；决策补救则进一步引入行动成本、可行性和因果约束。第 11 章检验预测是否可靠，本章研究支持理解和质疑的依据。

15.1 模型的可解释性

15.1.1 解释对象决定证据

解释至少需要明确对象、使用者和用途。开发者排查错误可能需要内部激活和训练样本；普通使用者判断一次结果可能只需要相关因素及其限制；受影响者寻求补救则需要知道可以采取什么行动。信息更多不一定更有用，解释必须能够支持当前判断。

还应区分模型的行为规律、计算机制和现实因果关系。观察年龄与模型输出相关，可以描述行为；改变模型输入中的年龄字段，可以检查模型是否使用它；在现实中改变年龄通常不是可行行动，更不能据此推断现实结果如何变化。三种论断的对象不同，不能只因为都使用“影响”一词就互

相替换。

15.1.2 整体解释与单次解释

整体解释（global explanation）是在明确的一组输入或参考分布上，用人能够理解的形式概括模型怎样作出判断。它可以是一套可执行规则、一组特征响应曲线，或关于某类样本的概念作用统计。这里的“整体”限定解释希望覆盖的范围，不表示解释一定包含全部内部计算，也不表示一个平均数已经适用于每个输入。解释邮件模型时，参考范围可以是部署中的全部邮件，也可以是事先声明的某种语言或某类业务邮件。

单次解释（local explanation）则把目标固定为一次输出，例如这一封邮件为什么被拦截。它可以比较当前输入附近的变化、相对于某个基准的分数差，或者当前运行中某项内部计算的作用。整体与单次解释的共同点是都要把模型行为和可核查的证据联系起来；区别在于待解释的范围和需要支持的论断。整体解释需要说明规律在参考人群中的覆盖程度，单次解释需要说明参照输入、邻域或具体运行条件。

两者能够相互连接。若已有准确的整体加性规则，将当前特征代入，就可以追踪一次预测；若已有许多单次归因，则可以在固定解释定义后统计贡献分布，形成总体摘要。但一次解释不能推出普遍规律，平均归因也可能掩盖方向相反的子群。对模型作输入输出查询，既能得到整体曲线，也能得到单次解释；是否读取内部参数是另一个划分维度，不与整体、局部一一对应。

示例 15.1 同一规则的整体与单次说明 设一个教学用邮件评分器读取两个二元特征： x_1 表示出现支付要求， x_2 表示出现可执行附件。其规则为 $f(x_1, x_2) = 1 + 2x_1 + 4x_2$ ，分数不小于 6 时隔离邮件。分数只是构造的模型打分，不是概率。整体说明需要交代基准分、两项增量和隔离阈值，因此覆盖四种特征组合。对当前邮件 (1, 1)，单次说明则是 $1 + 2 + 4 = 7$ ，超过阈值；相对于 (0, 0)，两项输入分别贡献 2 和 4。这一次代入不说明真实模型在其他组合上也按同样规则计算，整体主张还需要相应结构或查询证据。

图 15.1 沿用同一条教学规则。左侧检查解释覆盖哪些输入，右侧追踪一次代入；单次结果不能替代对整体范围的核验。

15.1.3 解释的表示与证据条件

一个稀疏线性模型或短规则列表通常便于追踪计算，但特征本身仍需有明确含义。若输入是一万个难以解释的嵌入维度，线性结构也未必让使用者理解决策。反过来，复杂模型的某个局部行为可能能够用简单规则准确描




图 15.1 示例 15.1 的整体与单次解释。左侧规则覆盖四种输入组合；右侧固定当前邮件 (1, 1)，把 7 分拆成基准分 1、支付要求贡献 2 与可执行附件贡献 4，并与隔离阈值 6 比较。这里的分数不是概率，贡献也不表示特征的现实因果作用。

述，却不能据此概括整个模型。

解释还会受到访问条件限制。只有输入输出查询时，主要依赖行为近似；能够读取参数和激活时，可以提出机制假设；能够重新训练时，才能更直接地检验某些训练数据影响。后续方法应在这些信息条件下理解，而不是将所有解释视为同一层次的证据。

解释通常还隐含一个比较问题。邮件为什么被拦截，可以指“为什么这一封被拦而相似邮件没有”，也可以指“为什么拦截而不是交给人工复核”。前者比较输入，后者比较行动；它们需要的分数、背景样本和约束不同。即使选择同一种归因算法，改变比较基准也可能改变答案。因此，一份可核查的解释应说明所解释的输出、参照对象、适用输入范围和允许改变的因素。

15.2 整体行为的解释

整体行为可以从模型结构、输入和语义三个方面理解。模型结构说明预测怎样由规则、函数或计算分支组成；输入分析说明改变哪些可观察因素会怎样改变输出；语义解释则把词元、像素或特征组合转换成读者关心的概念，考察模型是否利用这些含义。三者可以结合：一个模型可以采用可读结构，以输入特征计算，并通过语义概念表达其中的依据。下面按主要解释对象安排方法，不把这三个方面当成互斥的模型类型。

15.2.1 基于模型结构的解释

如果能让读者理解“模型遇到不同输入时按照什么规则计算”，可以从一开始就选择可读结构，或者在模型训练后用简单模型近似它。前者的规则属于实际预测器，后者的规则属于解释用的代理。两者都能提供整体说明，

但前者需要检验任务表现与结构可理解性，后者还必须检验是否忠实于原模型。

广义加性模型（generalized additive model, GAM）用若干单特征函数组成预测，使每项特征的作用可以单独查看，例如

$$f(\mathbf{x}) = \beta_0 + \sum_{j=1}^d f_j(x_j). \quad (15.1)$$

这里 β_0 为基准项， f_j 描述第 j 个特征的效应。回归时 f 可以直接作为预测值；二分类时，可令它表示对数几率，再用逻辑函数转换为概率。固定各函数的中心化约定，例如令其在训练分布上的平均值为零，可以分别查看变化趋势。曲线的陡峭区域说明模型对该特征变化敏感，数据稀少区域则需要同时展示样本覆盖，避免把不稳定估计误读为确定规律。

只允许相加会遗漏交互。邮件中的“支付”与“附件”单独出现都可能正常，同时出现才增加风险。Lou 等研究的带成对交互的加性模型在单变量项之外增加少量 $f_{j,k}(x_j, x_k)$ ，用二维曲面表达一项特征的作用如何随另一项改变。训练时既要选择哪些交互值得保留，也要控制各项复杂度；解释时则需要同时检查单变量曲线和交互曲面¹。

规则和树结构同样可以追踪决策路径，但规则数量、重复条件和层次深度会增加理解负担。把一棵树压缩成几条常见路径，也会漏掉低频分支。选择可理解结构时应在当前任务上同时检查预测损失与人能否完成预期判断，不能预先断言简单模型一定足够，也不能未经比较便认定复杂模型不可替代。

构建这类实际预测器时，训练数据提供真实标签，学习算法在加性结构、函数平滑性或树深度等限制下拟合任务。解释阶段固定训练结果，显示各项函数、阈值和交互，并说明如何将它们组合成输出。也就是说，可读的不是训练算法的名称，而是训练后能够被逐项追踪的计算规则。

对于已经训练好的复杂模型，可以另外建立**整体代理**（global surrogate），即在声明的参考分布上模仿原模型的简单预测器。具体做法是从该范围收集输入，查询原模型的分数，用这些分数作为拟合目标，再训练浅树、规则表或加性模型。设原模型为 f ，可读模型族为 G ，复杂度惩罚为 Ω ， $\lambda \geq 0$ 控制拟合误差与复杂度的权衡，则一种构造为

$$\hat{g} = \arg \min_{g \in G} \left\{ \frac{1}{n} \sum_{i=1}^n [f(\mathbf{x}_i) - g(\mathbf{x}_i)]^2 + \lambda \Omega(g) \right\}. \quad (15.2)$$

这里使用的是原模型输出 $f(\mathbf{x}_i)$ ，而非真实标签 y_i ；对真实标签重新训练一个小模型，不能自动解释原模型。分类时也可以拟合概率向量或类别，但选择哪一种目标，会决定代理保留分数变化还是仅保留决策边界。

¹ Y. Lou, R. Caruana, J. Gehrke, G. Hooker, *Accurate Intelligible Models with Pairwise Interactions* In Proceedings of the 19th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 2013

得到代理后，需要展示其实际规则，并在另外保留的查询样本上比较 g 与 f 。例如，浅树如果先检查附件，再检查支付要求，就能在示例 15.1 的四种组合上复述隔离规则；只写“有附件就隔离”则在 $(0, 1)$ 上与原模型不符。平均一致率很高而遗漏少数业务分支时，应保留分组误差，或将解释范围缩小到真正拟合良好的区域。增加代理复杂度通常能减少近似误差，却可能使解释重新变得难读。

15.2.2 基于输入的解释

整套代理试图给出一个能够重新计算预测的模型；如果只想知道“哪些输入怎样影响判断”，可以直接从原模型提取作用摘要，无须先学出整套规则。这就是本小节与上一小节的关系。摘要主要有两个互补问题：特征改变时，分数怎样响应；破坏该特征信息后，任务表现损失多少。前者描述作用形状和方向，后者度量固定模型对信息的性能依赖。

响应形状与交互 部分依赖 (partial dependence, PD) 分析考察把某个特征固定后，对其余特征取平均的输出：

$$PD_j(t) = \mathbb{E}_{\mathbf{x}_{-j}} f(t, \mathbf{x}_{-j}).$$

其中 $\mathbf{x}_{-j}$ 表示除第 j 个特征外的输入， t 为要考察的特征取值。

实际构建部分依赖曲线时，选取一组特征取值 t ，把参考样本的第 j 项都替换为 t ，逐一查询模型，再求平均：

$$\widehat{PD}_j(t) = \frac{1}{n} \sum_{i=1}^n f(t, \mathbf{x}_{i,-j}).$$

将这些均值随 t 画出，就得到上升、下降、阈值或饱和的形状。若同时考察两个特征，则对二维取值网格作同样替换和平均，以检查一个特征的作用是否随另一个改变。只展示一条平均曲线时，还应检查各输入的响应曲线是否方向一致。

沿用示例 15.1，若四种输入组合在参考群体中等概率出现，则 $PD_1(t) = 3 + 2t$ ， $PD_2(t) = 2 + 4t$ 。这些曲线概括支付要求和附件对平均分数的作用，却没有给出每封邮件的分数，更没有使用真实标签判断模型是否正确。若参考群体改变，平均曲线的截距也可能改变；在这个没有交互的例子中，斜率仍由规则中的 2 与 4 决定。

这种替换也可能组合出现现实中不存在的样本。若所有观测满足 $x_1 = x_2$ ，模型为 $f(x_1, x_2) = x_1 - x_2$ ，它在观测数据上恒为零；单独改变 x_1 却会得到上升趋势。趋势描述的是模型对这些组合的响应，不能直接解释为观测人群中的实际效应。

条件平均使用给定特征后的其余特征分布,避免部分不现实组合,却会混合特征关联。因此,即使画出的都是一条“特征—输出”曲线,也需要说明固定了什么、对什么分布取平均。

为了减少跨越数据支持区域的外推, Apley 与 Zhu 提出**累积局部效应**(accumulated local effects, ALE): 只在某特征当前取值附近估计小幅变化的平均作用, 再将这些局部作用沿该特征累积。对适当光滑的模型, 一阶形式为

$$\text{ALE}_j(t) = \int_{t_0}^t \mathbb{E} \left[\frac{\partial f(s, \mathbf{x}_{-j})}{\partial s} \middle| \mathbf{x}_j = s \right] ds - C_j, \quad (15.3)$$

其中 t_0 为积分起点, C_j 用于中心化。实际计算通常把特征值分箱, 在每箱已有样本上比较箱边界处的输出, 再累加平均差值; 不必求模型导数²。

部分依赖平均的是整个预测值, 累积局部效应平均的是局部变化, 这正是两者的差别。后者降低了不现实组合造成的外推问题, 但分箱太粗仍会跨过无数据区域, 分箱太细又可能估计不稳。它也不是从观测数据识别现实因果作用的方法: 同一模型函数在数据流形以外如何延伸, 仍可能影响其局部偏导。若要理解个体差异, 可以保留每个样本随特征变化的曲线, 检查总体平均掩盖了哪些交互。

² D. W. Apley, J. Zhu, *Visualizing the Effects of Predictor Variables in Black Box Supervised Learning Models* In Journal of the Royal Statistical Society Series B: Statistical Methodology, 2020, vol. 82, no. 4, pp. 1059–1086

任务表现对信息的依赖 响应曲线说明分数如何变化, 却没有使用真实结果来判断这些变化是否有助于完成任务。若要检查模型是否依赖邮件页脚来正确分类, 需要比较保留与破坏这项信息时的预测损失。这个问题以任务表现为参照, 因此不同于读取曲线斜率或系数大小。

置换重要性固定已训练的模型, 将测试集中某项特征在样本间打乱, 再比较平均损失与原始损失。实际检验应在同一批测试样本上作成对比较, 重复置换, 报告损失增量的均值和波动。若打乱页脚后错误明显增加, 得到的是模型在这种信息破坏下的性能依赖证据; 它既不证明页脚具有现实因果作用, 也不直接说明这种依赖合理。

把置换过程写开, 可以更清楚地看到解释的对象。设 π 为样本索引的随机排列, $\mathbf{x}_i^{(j, \pi)}$ 只把样本 i 的第 j 项替换成 $x_{\pi(i), j}$, 则一次损失增量为

$$\hat{\ell}_j^{(\pi)} = \frac{1}{n} \sum_{i=1}^n [\ell(f(\mathbf{x}_i^{(j, \pi)}), y_i) - \ell(f(\mathbf{x}_i), y_i)]. \quad (15.4)$$

需要真实标签的是损失比较, 原模型在置换前后始终不重训练。以零一损失为例, 若一个教学测试集有 100 封邮件, 原来误判 10 封, 一次置换附件字段后误判 25 封, 则这次增量为 0.15。重复置换得到的均值和波动, 分别描述该破坏规则下的平均性能变化与置换随机性; 对新邮件总体的推广还要考虑测试样本的不确定性。

关联特征使参照尤其重要。若页脚与发送方始终配套, 单独打乱页脚可

能制造不现实组合，损失增量同时包含这种分布外效应。按发送方分组后置换，考察的是给定发送方后页脚剩余信息的作用；把相关特征作为一组置换，则考察这组信息的共同作用。若模型只读取两个相互替代的特征之一，另一项的置换重要性可以为零，但不能由此断言它在数据中不含预测信息。这里检验的是固定模型的使用方式，删除特征后重新训练比较的是学习系统能否找到替代依据，两者需要分别报告。

曲线与重要性因而不应互相代替。分数对某特征变化明显，但变化没有跨过分类阈值时，零一损失的重要性可能很小；模型若错误利用某项信息，破坏它甚至可能降低损失。响应曲线回答模型如何变化，损失增量回答这种依赖对所选任务指标意味着什么。要判断依赖是否合理，还需结合任务语义和使用要求。

15.2.3 基于语义的解释

输入层的分析仍可能离读者关心的含义很远。例如，“催促付款”可以由许多不同词语表达，同一个词也可能出现在引用或警示中。基于语义的解释用“来源可验证”“要求立即转账”等概念描述依据，再检查这些概念怎样影响输出。构建途径有两种：让模型直接通过命名概念作出预测，或者在已有模型中寻找与概念对应的表示并检验其作用。

Koh 等研究的**概念瓶颈模型**（concept bottleneck model）先将输入映射为人定义的概念，再只通过这些概念预测结果。它把可查看、可修改的语义接口放进模型的实际计算路径，而不只在预测之后附加描述³。

设概念向量为 $\mathbf{c} \in \mathbb{R}^m$ ，概念预测器为 g ，决策函数为 h ，则 $f(\mathbf{x}) = h(g(\mathbf{x}))$ 。有概念标注时，可以先用概念损失训练 g ，再用预测概念或真实概念训练 h ；也可以联合优化任务损失与概念损失。不同方式改变了任务信号能否反过来调整概念表示，以及训练和使用概念误差是否匹配。若人工确认邮件来源有效，便可替换相应概念值，观察最终判断是否得到纠正。

要据此给出整套决策规则，还需说明决策函数 h 怎样组合概念，例如展示其加性项、阈值或规则路径。若 h 本身仍是难以理解的复杂网络，概念瓶颈提供的是可检查的语义接口，并没有自动解释整套计算。对概念作用作整体判断，还需在覆盖目标任务的样本上检验，而不能只展示一次纠错。

接口具有名称也不代表语义已经得到保证。概念预测错误会向后传播；遗漏重要概念会限制任务能力；连续概念分数还可能携带超出标注名称的信息。若模型另有绕过瓶颈的输入通路，修改概念后也未必能控制全部依据。验证时应检查概念预测质量、概念替换效果和任务损失，而不能只展示若干容易命名的中间节点。

若不希望重新训练概念瓶颈模型，也可以在已有表示中检验一个明确的概念假设。Kim 等提出的**概念激活向量检验**（testing with concept activation

³ P. W. Koh, T. Nguyen, Y. S. Tang, S. Mussmann, E. Pierson, B. Kim, P. Liang, *Concept Bottleneck Models* In Proceedings of the 37th International Conference on Machine Learning, 2020, pp. 5338–5348

vectors, TCAV) 把概念表示成内部空间中的方向, 再检查模型对该方向是否敏感。方法使用带有目标概念和对照概念的样本, 在某层激活空间训练线性分隔器, 得到指向目标概念一侧的方向 $\mathbf{v}_C$ 。它再考察类别分数沿该方向的导数, 统计一类样本中导数为正的比例。这样, “模型是否使用某种纹理” 被转化为可以重复测量的局部敏感性问题⁴。

若某层激活为 $\mathbf{h}(\mathbf{x})$ 、该层之后的类别分数为 $s_k(\mathbf{h})$, 被统计的量是 $\nabla_{\mathbf{h}} s_k(\mathbf{h}(\mathbf{x}))^\top \mathbf{v}_C$ 的符号。结果依赖概念样本、对照集和网络层, 因此需要更换对照、重复拟合并报告不确定性。概念方向能分开两组样本, 可能源自与概念共现的背景; 导数为正也只是表示空间中的敏感性, 不能直接解释为现实中增加该概念就会提高该类概率。与概念瓶颈相比, TCAV 增加了事后检验能力, 却没有强制模型只能通过被命名的概念作决策。

具体实施时, 需要三组具有不同职责的数据: 概念实例及其对照用于学习方向, 目标类别或任务样本用于计算作用, 另留的概念和任务样本用于复核。固定模型与层之后, 记录概念样本的激活, 用线性分类器分开概念与对照, 并将法向量朝概念一侧定向。随后在每个目标样本上计算类别分数沿该方向的导数。对目标样本集合 D_k , 一种摘要为

$$\hat{t}_{C,k} = \frac{1}{|D_k|} \sum_{\mathbf{x} \in D_k} \mathbf{1}\{\nabla_{\mathbf{h}} s_k(\mathbf{h}(\mathbf{x}))^\top \mathbf{v}_C > 0\}.$$

若 100 个待解释样本中有 80 个方向导数为正, 统计量就是 0.8, 含义是这些样本中有八成在该表示方向上呈正局部敏感性。它不是 “该概念贡献了 80% 的预测”, 也不代表八成预测由它单独决定。更换概念实例和随机对照后仍能重复发现这种差别, 才更支持所提出的概念假设。

模型结构、输入和语义的关系也由此明确: 结构交代怎样组合证据, 输入分析检验具体字段或区域的作用, 语义解释说明这些依据对应什么含义。概念瓶颈通过改变结构提供语义接口, 概念激活检验则借助已有表示分析语义; 同一种方法可以连接多个方面。无论从哪一方面形成整体结论, 都要说明样本覆盖、汇总方式以及不同输入间是否存在相反作用。

15.3 单次行为的解释

同一次预测可以从三个方面解释。基于推理输入的解释, 研究当前输入及其变化与输出有什么关系; 基于推理计算过程的解释, 研究模型通过哪些计算形成这次输出; 基于训练数据的解释, 则把当前判断追溯到训练阶段, 研究哪些训练经验影响了它。以误拦邮件为例, 三个方面分别检查触发判断的邮件内容、处理这些内容的计算环节, 以及使模型学会这种判断的训练样本。

相似案例、反事实比较、局部代理和特征归因都属于第一个方面: 它们固定已经训练好的模型, 通过参照案例、输入变化或贡献分配理解当前结

⁴ B. Kim, M. Wattenberg, J. Gilmer, C. Cai, J. Wexler, F. Viegas, R. Sayres, *Interpretability Beyond Feature Attribution: Quantitative Testing with Concept Activation Vectors (TCAV)* In Proceedings of the 35th International Conference on Machine Learning, 2018, pp. 2668–2677

果。推理计算过程的解释进一步检查预测过程中的作用位置；训练数据解释则研究改变学习经历后，同一输入的预测会怎样变化。这里按解释所要说明的对象分组，而不是按算法名称或是否读取内部参数分组。三个方面可以独立提供证据，也可以相互核验。

选择方法前应固定要解释的输出。例如，垃圾邮件分数、最终隔离动作和“隔离而非人工复核”的选择并不相同。若最终动作还受规则阈值或权限约束控制，仅解释分类分数会遗漏后续决策。下面主要把 $f(\mathbf{x})$ 视为待解释的标量分数，用 $\hat{y}(\mathbf{x})$ 表示结合决策规则后得到的类别或动作；多类别模型还需固定所解释的目标类别。

15.3.1 基于推理输入的解释

这一类解释固定模型，围绕当前输入寻找参照或构造变化，再将输入差异与输出联系起来。相近输入得到相同结果，可以提供共同特征的线索；相近输入得到不同结果，可以提示判断的边界；对多种输入变化作系统比较，则可以刻画响应规律或分配特征贡献。这些比较的共同对象都是推理时的输入与输出，差别在于希望得到案例对照、响应规则还是贡献数值。

并非每种方法都要实际修改原样本：可以检索已有案例，也可以利用模型导数计算局部变化。输入不同而最终类别相同，分数仍可能明显改变；因此，解释还要区分所比较的是类别、分数还是最终动作。

相似案例的对照 一种直观解释是展示与当前输入相似、并被模型作出相同判断的案例。例如，当前邮件含有支付要求与可执行附件，并被模型隔离，可以展示内容相近、同样包含这两个因素的已隔离邮件，并标明共同片段。读者由此看到当前案例被放到了怎样的一组案例中，而不必先读一组抽象权重。这通常称为**基于案例的解释**（example-based explanation）。

构造时，需要先规定相似性：按词语、业务字段还是模型表示比较，哪些差异可以忽略；再从参考库中选出模型结果相同的近邻，呈现共同点、差异和距离。若参考案例有真实标签，还应同时显示标签与预测，避免把一组相似误判展示成判断正确的证据。可以选多个近邻，或挑选有代表性的案例作为原型，减少只展示某个偶然例子的影响。

这种比较首先提供的是理解线索。如果模型本来就接近邻或原型相似度预测，显示实际参与投票的案例及其权重，就能追踪决策的一部分；如果模型独立作出预测后才检索相似案例，检索结果只是事后对照，还不能证明模型用了这些共同特征。需要进一步改变共同特征、比较输出，才能检验这条解释。

Chen 等提出的原型部件网络 ProtoPNet 把案例比较纳入图像分类：比较当前图像局部与学得原型的表示相似度，再加权形成类别分数。原型与

训练图像片段关联，使解释能够同时展示“当前哪一块像哪个典型片段”及其对类别分数的作用。这提供了案例比较属于实际预测过程的一种实现⁵。

相似性也需要检查。模型表示可能把背景当作相似依据，人却以为它比较的是物体；邮件模板相似，也不表示业务意图相同。因此应显示相似的具体位置，并核对贡献权重，不能只给两个完整案例便让读者自行推断比较依据。对当前结果的理解，还需要观察相近但结果不同的案例。

不同结果的反事实比较 相似案例说明“这一输入像哪些同结果案例”，不同结果的比较则追问“哪些差别足以使判断不同”。可以从真实数据中寻找与当前输入接近、但预测不同的案例，逐项比较字段；也可以主动构造新的输入，只改变少量条件并再次查询模型。后者更便于控制其他因素，明确结果依赖的条件。

Wachter 等讨论的**反事实解释** (counterfactual explanation) 寻找接近当前输入、却得到目标输出的另一输入。常见计算形式是最小化距离与目标输出损失的加权和；也可以把达到目标写成约束。它把“为何是这个结果”转化为“哪些条件改变后便不再是这个结果”⁶。

设 Y_{target} 是与当前结果不同的目标结果集合， d 衡量输入差异， $\mathbf{X}_{\text{valid}}$ 规定本次解释中允许考虑的有效输入，则一种构造为

$$\min_{\mathbf{x}' \in \mathbf{X}_{\text{valid}}} d(\mathbf{x}', \mathbf{x}), \quad \hat{y}(\mathbf{x}') \in Y_{\text{target}}. \quad (15.5)$$

实际搜索可以从已有的不同结果案例开始，也可以在允许字段上枚举、使用梯度或优化求解。得到候选后必须重新运行完整预测规则，检查目标结果确实改变，并列出了修改了哪些字段。距离可以偏好只改变少数因素；连续变量的尺度、离散变量的取值和字段间的有效组合需要事先说明，否则“最近”可能仅由单位选择决定。有限搜索找到一个候选，不等于已经证明它最小或唯一。

沿用示例 15.1，当前 (1, 1) 得 7 分而被隔离。保留支付要求、把可执行附件改为非可执行形式，输入成为 (1, 0)，得 3 分；保留附件、去掉支付要求，输入成为 (0, 1)，得 5 分，两者都会被放行。这两个反事实分别表明：在另一条件保持时，改变任一项都足以越过当前决策边界。若只展示第一个，就容易让人误以为附件是唯一决定因素。

反事实因此可以定位本次结果所依赖的条件，但结论相对于模型、允许改动和参照成立。真实的不同结果近邻若同时改变多个字段，只能提示差异；受控地改变字段并重算模型，才进一步检验这些改动对预测的作用。即使找到了这样的条件，也尚未证明现实结果由它造成，更没有说明使用者能够实施该改动。前者需要额外的因果依据，后者由第 15.5 节讨论。

⁵ C. Chen, O. Li, C. Tao, A. J. Barnett, J. Su, C. Rudin, *This Looks Like That: Deep Learning for Interpretable Image Recognition* In *Advances in Neural Information Processing Systems*, 2019

⁶ S. Wachter, B. Mittelstadt, C. Russell, *Counterfactual Explanations without Opening the Black Box: Automated Decisions and the GDPR* In *Harvard Journal of Law & Technology*, 2018

图 15.2 用后文示例 15.3 的连续申请规则说明“最近”的含义：模型在 $s + r \geq 3$ 时批准，当前 $(1, 1)$ 被拒绝。若只按欧氏输入距离寻找批准点，最近位置是 $(1.5, 1.5)$ 。这一步没有计算培训、资源支持等行动的后果与成本，因此不能把最近输入直接当成最低成本补救。




图 15.2 连续输入下的最近模型反事实。批准区域含边界 $s + r = 3$ ，两项坐标等权计入欧氏距离；从拒绝点 $(1, 1)$ 作垂直投影，得到唯一最近点 $(1.5, 1.5)$ ，距离为 $1/\sqrt{2}$ 。虚线圆表示相同输入距离，直角标记显示投影垂直于边界。这里仅优化输入距离，未加入实际行动约束；可行行动与成本另见图 15.5。

案例对照和反事实给出具体参照输入。若希望更系统地说明哪些词语、像素或字段支持当前输出，可以在附近构造多种输入变化，观察输出规律，或者把当前分数相对于基准的差异分配给各项输入。下面的方法共享输入与输出这一比较对象，区别在于拟合附近的响应规则、测量单项变化，还是分配相对于基准的贡献。

附近输入的响应规则 局部代理方法在一个输入附近查询模型，用简单模型近似这一区域的行为。**局部可解释模型无关解释**（local interpretable model-agnostic explanations, LIME）根据与待解释输入的接近程度加权拟合，并限制代理复杂度。邻域如何采样、距离如何定义以及代理误差多大，都会影响解释⁷。

以邮件为例，可以用词语是否保留构造二元向量 $\mathbf{z}$ ，通过映射 $r(\mathbf{z})$ 得到

⁷ M. T. Ribeiro, S. Singh, C. Guestrin, "Why Should I Trust You?": Explaining the Predictions of Any Classifier In arXiv preprint arXiv:1602.04938, 2016

可查询的文本，再拟合稀疏线性代理 g ：

$$\hat{g} = \arg \min_{g \in G} \left\{ \sum_{i=1}^n w_{\mathbf{x}}(\mathbf{z}_i) [f(r(\mathbf{z}_i)) - g(\mathbf{z}_i)]^2 + \lambda \Omega(g) \right\}. \quad (15.6)$$

这里 G 为候选代理模型族， $w_{\mathbf{x}}$ 强调与当前邮件接近的扰动， Ω 惩罚代理复杂度， $\lambda \geq 0$ 控制惩罚强度。权重范围越窄，代理越侧重当前点附近，却可能缺少足够变化来估计系数；范围越宽，则更难用简单模型覆盖复杂行为。删词可能破坏语法甚至改变邮件目的，因此必须检查生成邻域是否符合解释任务，并在另采样的邻域中报告拟合误差。稀疏系数只是这个加权近似问题的答案。

实际计算时，LIME 先把当前邮件表示为可读的词项保留向量，采样若干删词组合，取得原模型对这些组合的分数；再按接近程度加权，用少量非零系数拟合这些分数。最后交付的是所选词项、系数方向和大小，以及代理在声明邻域中的误差。原模型不需要因此重新训练。

若待解释模型恰好是示例 15.1 的加性规则，邻域又包含足以识别两项作用的组合，未加稀疏惩罚的线性拟合便能恢复系数 2 和 4。但真实模型存在交互时，同一词在另一封邮件附近可能得到不同系数。这也说明整体代理与 LIME 共享“查询后拟合”的思想，差别在于拟合数据和误差权重覆盖整个参考范围，还是围绕当前输入集中。

邻域规则可以告诉人哪些附近输入会改变判断，却未必说明当前输出由哪些证据支持。证据归因针对当前输出标记或分配各项输入信息的作用：有些方法只标记敏感位置，有些方法还要求各项贡献加起来等于某个分数差。后者需要固定比较基准或特征组合的评价规则。归因数值的含义由这些约定决定，不能直接解释为现实原因。

扰动比较与局部敏感性 只需查询模型的一种做法是遮挡输入：把当前第 j 项替换成规定的参照值，计算原分数减去替换后的分数。对文本可以移除或替换词段，对图像可以替换区域。重复这一操作就得到输入位置的作用图。这里得到的是单项移除效果；有交互或冗余时，所有移除效果之和未必等于总分数差。选择什么替换值，仍是解释定义的一部分。

对于可微分函数 f ，梯度说明小幅改变输入时输出的局部敏感性。它可能在饱和区域接近零，即使该特征曾对输出形成过程十分重要。仅有终点敏感性还不足以分配当前分数相对于基准的变化，需要另外规定沿途如何累计。

相对于基准的贡献分配 积分梯度 (integrated gradients, IG) 沿基准 $\mathbf{x}_0$ 到

输入 $\mathbf{x}$ 的路径累计导数：

$$\text{IG}_j(\mathbf{x}) = (x_j - x_{0,j}) \int_0^1 \frac{\partial f(\mathbf{x}_0 + t(\mathbf{x} - \mathbf{x}_0))}{\partial x_j} dt. \quad (15.7)$$

令 $\gamma(t) = \mathbf{x}_0 + t(\mathbf{x} - \mathbf{x}_0)$ ，并记 $\varphi(t) = f(\gamma(t))$ 。若 φ 在 $[0, 1]$ 上绝对连续，每个坐标对应的 $t \mapsto (x_j - x_{0,j}) \partial f(\gamma(t)) / \partial x_j$ 都可积，且几乎处处满足

$$\varphi'(t) = \sum_j \frac{\partial f(\gamma(t))}{\partial x_j} (x_j - x_{0,j}),$$

则微积分基本定理给出 $\sum_j \text{IG}_j(\mathbf{x}) = f(\mathbf{x}) - f(\mathbf{x}_0)$ 。 f 在包含整条线段的邻域内连续可微，是一项容易检查但更强的充分条件；分段光滑模型也可使用该等式，但必须确认路径复合函数绝对连续，并且所取导数在几乎处处满足上述链式关系。若路径沿不可微集合移动而所用导数不代表路径导数，就不能直接调用完整性等式。

这个等式说明贡献解释了相对于基准的分数差，却不赋予基准或路径现实因果含义。Sundararajan 等从归因公理出发提出这一方法；黑色图像、空文本或平均输入是否适合作为基准，仍需要由任务判断⁸。积分梯度能够累计路径中经过的敏感区域，而最终点的梯度只描述终点。对于离散文本，在词嵌入之间插值只是计算路径，路径上的向量未必对应任何合法句子。有限个插值点得到的是数值积分近似，即使理论条件成立，贡献和也只会是在求积误差范围内接近端点分数差；应报告求和残差，不能把数值误差当成模型遗漏的证据。

实际求积分梯度时，选择基准与当前输入之间的若干插值点，在每点计算目标分数的输入梯度，求平均后乘以各维输入差。示例 15.1 在 $(0, 0)$ 到 $(1, 1)$ 的路径上梯度始终为 $(2, 4)$ ，因此贡献为 2 和 4，总和为 $7 - 1 = 6$ 。这说明了如何从模型计算得到解释数值；换成另一个基准后，被分配的分数差也会改变。

图 15.3 把这个可复算的贡献分配对应到邮件中的两项输入。条长比较相对于固定基准的分数增量，不表示它们造成现实损害的程度。

Shapley 值将贡献分配理解为不同特征组合带来的增量。若 $N = \{1, \dots, d\}$ ， $v(S)$ 表示保留特征子集 S 时的约定价值，则第 j 个特征的分配为

$$\phi_j = \sum_{S \subseteq N \setminus \{j\}} \frac{|S|!(d - |S| - 1)!}{d!} [v(S \cup \{j\}) - v(S)]. \quad (15.8)$$

SHAP (Shapley additive explanations) 利用这类加性归因解释模型预测，即把相对于基准的分数变化分配给各项特征。关键仍是 $v(S)$ 的定义：缺失特征如何填补、是否使用条件分布，会改变被解释的问题和结果⁹。

一种选择是将未保留特征从背景分布采样，令 $v(S) = \mathbb{E}[f(\mathbf{x}_S, \mathbf{X}_{-S})]$ ；另

⁸ M. Sundararajan, A. Taly, Q. Yan, *Axiomatic Attribution for Deep Networks* In Proceedings of the 34th International Conference on Machine Learning, 2017, pp. 3319–3328

⁹ S. Lundberg, S.-I. Lee, *A Unified Approach to Interpreting Model Predictions* In arXiv preprint arXiv:1705.07874, 2017




图 15.3 教学邮件规则的特征归因。基准 (0,0) 得 1 分，当前 (1,1) 得 7 分；沿直线路径的梯度恒为 (2,4)，积分梯度归因分别为 2 与 4，合计 6。输入标记与贡献条一一对应，条长从零开始。邮件文字只承载已定义的二元特征；归因不是概率，也不证明现实因果关系。

一种选择按已观测特征条件采样。前者更直接研究模型在人工组合上的响应，后者保留数据关联，但可能把贡献分给模型未直接读取、却能预测其他特征的变量。两者回答不同问题，并不存在脱离任务的唯一“真实贡献”。精确计算还要处理指数数量的子集，实际算法需要利用模型结构或采样近似，报告背景集与近似误差。

可以把 Shapley 计算理解为反复随机排列特征的进入顺序。在每一种顺序中，从背景开始逐项加入当前输入的特征值，记录加入第 j 项前后的价值差；对所有顺序取平均，就得到式 (15.8)。特征很多时采样一部分顺序近似。其产物仍是一组当前输入的贡献，区别于积分梯度的是比较不同特征组合，而不是沿一条连续输入路径累计梯度。

示例 15.2 共同信息的贡献分配 在一个构造的两特征问题中，令 $v(\emptyset) = 0$, $v(\{1\}) = v(\{2\}) = v(\{1, 2\}) = 1$ 。两项信息互相替代，任一项都足以达到价值 1。Shapley 分配对每项给出 $1/2$ ：它平均了该特征先进入或后进入的增量。这个数不表示删除任意一个特征会让完整模型输出降低一半。

支持区域的定位 图像中的归因还可以以区域而非输入坐标为单位。此时人常常只需要先找到支持当前类别、值得进一步检查的位置。Grad-CAM 将目标类别分数对某层卷积特征图的梯度作空间平均，以此给不同通道加权，再保留加权后的正值区域。若第 k 个通道的特征图为 $\mathbf{A}^k$ ，空间位置

数为 Z ，目标类别分数为 s_c ，则

$$\alpha_k^c = \frac{1}{Z} \sum_{i,j} \frac{\partial s_c}{\partial A_{i,j}^k},$$

$$L_{i,j}^c = \max\left(0, \sum_k \alpha_k^c A_{i,j}^k\right). \quad (15.9)$$

梯度指出哪些通道对当前类别分数敏感，特征图提供这些通道在空间中的响应，二者结合形成粗粒度定位。Selvaraju 等用这一机制解释多种卷积网络的类别相关区域¹⁰。

定位图与积分梯度的目标不同：前者强调某层表示中支持目标类别的区域，后者分配相对于输入基准的分数差。Grad-CAM 的分辨率受所选层限制，空间平均会丢失通道内的差异，保留正值还会隐藏反对该类别的证据。上采样后的清晰边缘不能被理解为像素级因果结论。同一图像应检查不同目标类别和对照区域，避免把“看起来像目标物体”当成唯一依据。

15.3.2 基于推理计算过程的解释

前一小节把当前结果与推理输入联系起来，但尚未说明这些信息在模型中怎样参与计算。推理计算过程的解释固定已训练的参数，检查预测过程中哪些表示、组件或通路影响了输出。读取内部激活后，可以寻找编码某种概念的方向，再通过替换、屏蔽或恢复激活检查行为变化。能够从激活解码某个信息，说明该信息存在于表示中，却不说明当前决策使用了它。干预更接近检验计算作用，但也可能制造训练时从未出现的内部状态，因此需要合适的对照。

一种具体做法是保留原输入的干净运行，再构造使目标行为受损的输入，把干净运行中某个位置的激活替换进受损运行。如果目标输出恢复，便获得该位置在这一干预设置中参与行为的证据。Meng 等的因果追踪研究用这种思路定位语言模型事实关联的相关计算，并进一步以参数编辑检验机制假设。局部恢复不能证明信息只储存在该位置，因为替换值可能携带多个因素，其他通路也可能冗余地保存信息¹¹。

把这一方法落实到一次预测，需要分别保存干净运行的激活和目标分数，进行受损运行，再只在选定层、位置或组件上换回干净激活，继续向前计算。设三次目标分数为 s_{clean} 、 s_{corrupt} 和 s_{patch} ，且前者大于受损分数，可以用

$$r_{\text{restore}} = \frac{s_{\text{patch}} - s_{\text{corrupt}}}{s_{\text{clean}} - s_{\text{corrupt}}} \quad (15.10)$$

描述此次替换恢复了多少分数差。在一个构造例子中，三个分数分别为 4、0 和 3，恢复比例就是 0.75。它表示当前替换实验恢复了四分之三的差值，不表示该组件存储了四分之三的知识。比例也可能为负或超过 1，分母太

¹⁰ R. R. Selvaraju, M. Cogswell, A. Das, R. Vedantam, D. Parikh, D. Batra, *Grad-CAM: Visual Explanations from Deep Networks via Gradient-based Localization* In Proceedings of the IEEE International Conference on Computer Vision, 2017

¹¹ K. Meng, D. Bau, A. Andonian, Y. Belinkov, *Locating and Editing Factual Associations in GPT* In Advances in Neural Information Processing Systems, 2022

小时则很不稳定。逐个改变位置形成恢复图，再用其他输入配对和对照替换复查，才能提出较有依据的计算通路假设。

这与输入归因的区别在于解释的论断：归因把输出差分配给输入因素，机制干预询问内部哪一段计算在操作下影响输出。二者都可能使用梯度或激活，因此不能仅凭“使用了内部信息”来划界。例如 Grad-CAM 虽然读取内部特征图，交付的主要是输入区域定位；激活替换则直接比较改变内部计算前后的行为。输入归因有助于提出机制假设，内部干预再检验其中一部分，两者没有自动等价关系。

干预需要把必要性与充分性分开。移除某组件使行为消失，支持它在当前设置中的必要性；仅恢复该组件便挽救行为，支持它在特定背景下的恢复作用。改变污染输入、替换位置或评分目标可能改变结论。通过多种输入配对、等强度随机替换和组合消融检验，可以逐步排除简单的替代解释；单个成功案例尚不足以得到完整计算图。

对一次工具调用或一段生成过程，解释单位也可以扩展为行动序列。此时应追踪哪一步引入了关键证据，哪一步改变了后续选择，以及恢复某一步是否能够纠正结果。只看最终文本可能遗漏真正造成错误的中间行动。

15.3.3 基于训练数据的解释

前两小节固定已经训练好的模型，分别解释推理输入的作用和内部计算。若怀疑某次误判源于训练集中的错标样本，就需要把当前结果追溯到学习阶段：改变哪些训练样本后，模型对这封邮件的判断会发生变化？训练样本同样包含输入，但它在这里通过训练过程影响模型参数；在监督学习中，样本标签也参与这种影响。分析时保持待解释邮件不变，改变训练样本、标签或权重，研究学得模型的预测变化。因此，训练数据影响不同于前文对当前邮件删词后直接重算分数。

删除样本后重新训练是直接参照，但代价较大。影响函数在局部光滑条件下，用最优解对样本权重的导数近似这种变化。设训练目标为 $\hat{R}(\theta)$ ，局部最优解为 $\hat{\theta}$ ，该点处可逆的海森矩阵（Hessian matrix）为 $\mathbf{H}$ 。将目标改为 $\hat{R}(\theta) + \epsilon \ell(z, \theta)$ ，并沿原局部解附近的平稳点分支得到 $\hat{\theta}_\epsilon$ ，则

$$\left. \frac{d\hat{\theta}_\epsilon}{d\epsilon} \right|_{\epsilon=0} = -\mathbf{H}^{-1} \nabla_{\theta} \ell(z, \hat{\theta}).$$

这个关系来自对一阶最优条件求导。它依赖局部解和光滑性，大幅删除、非唯一解或重新训练路径变化可能使近似失准。Koh 与 Liang 研究了这种近似在模型预测追溯中的应用；训练数据归因仍应通过部分重训练或受控修改验证，而不能把近似分数直接当作数据来源的确定证明¹²。

若要解释测试样本 z_* 的损失，还需左乘 $\nabla_{\theta} \ell(z_*, \hat{\theta})^\top$ 。由此得到的负梯度内积经过逆海森矩阵调整，衡量增加训练样本权重时测试损失的局部变

¹² P. W. Koh, P. Liang, *Understanding Black-box Predictions via Influence Functions* In Proceedings of the 34th International Conference on Machine Learning, 2017, pp. 1885–1894

化。它不同于找输入最相似的训练样本：外观相近的两封邮件可能产生不同梯度，而一个不相似的错标样本也可能显著改变决策边界。大型模型通常通过海森矩阵与向量的乘积近似求解线性系统，不必显式存储整个逆矩阵；但近似计算并不会消除局部最优假设。

若训练没有达到稳定最优点，可以改为追踪训练过程。TracIn 考察使用某训练样本更新参数时，待解释样本的损失改变多少。对单样本梯度下降，一阶展开给出

$$\ell(z_*, \theta^{(t)}) - \ell(z_*, \theta^{(t+1)}) \approx \eta_t \nabla \ell(z_*, \theta^{(t)})^\top \nabla \ell(z_i, \theta^{(t)}).$$

其中 η_t 为第 t 步学习率，梯度均对模型参数求取。Pruthi 等据此在保存的训练检查点上累积梯度内积，近似识别有助于降低或增加该损失的训练样本。它避开了最终海森矩阵求逆，但需要检查点，并依赖更新步长、批处理和优化器；检查点近似也不等于删除样本后从头训练的反事实结果¹³。

¹³ G. Pruthi, F. Liu, S. Kale, M. Sundararajan, *Estimating Training Data Influence by Tracing Gradient Descent* In Advances in Neural Information Processing Systems, 2020

15.4 解释的质量

相似案例、反事实、输入贡献和计算追踪都给出了理解结果的线索，还需检验这些线索能否支持所作的说明。本章按五个问题组织评价：解释是否符合被解释模型，解释覆盖了声称的行为范围，重复计算与合理变化下是否稳定，人能否正确理解，以及这种理解是否改善实际使用。它们分别对应忠实性、完整性与覆盖、稳定性、可理解性和使用有效性。这里是一组需要分别核对的维度，不存在一个能够无条件汇总所有解释的通用分数。

评价应先固定模型版本、目标输出、输入范围、基准或干预规则 and 解释使用者。整体规则、特征摘要、单次归因与内部机制的论断不同，忠实性测试也必须匹配；对所有方法一律画一张删除曲线，会检验错对象。下面先说明每个维度的判断含义，再给出可以实际执行的比较。

图 15.4 选取忠实性、覆盖范围与稳定性，比较两套构造检查方案在这三方面纳入了多少检查项。它提醒读者分开补足证据，不用于评价真实模型优劣；可理解性与使用有效性仍需后续独立检验。

15.4.1 忠实性

忠实性 (fidelity) 指解释是否准确反映它声称描述的模型行为。被解释模型在任务上可能错误，解释却可以忠实地暴露这种错误依据；因此，解释忠实性与模型预测正确率需要分开。

对相似案例，应先复核相似度和输出是否符合检索条件，再区分案例只是事后参照，还是实际参与了预测。近邻模型可以重新计算邻居投票，原型模型可以核对相似度与类别权重；事后检索若声称共同特征解释了当前




图 15.4 解释质量检查的覆盖示意。每个维度预设四项检查，构造方案甲分别纳入 4、2、1 项，乙纳入 2、4、3 项；径向值仅为纳入项数除以 4，圆点实线与方点虚线区分方案。检查项的内容与难度在真实评价中须事先声明；此图不是算法实测评分，面积不用于汇总或认证解释质量，也没有替代其他两个评价维度。

结果，还需通过改变这些特征检验输出。只证明两例相似，不足以检验关于模型依据的主张。

对反事实，直接检查候选经过完整系统后是否得到目标结果，并报告输入距离、修改数量和有效性约束。若声称某项改动不可缺少，可以撤销该改动后重算；多项改动存在交互时，需要比较其组合。还应搜索其他相近反事实，检查解释是否只选了一条有利路径。是否能通过现实行动实现，是补救有效性的额外检验，不能用预测翻转代替。

对整体或局部代理，在未参与拟合的查询样本上同时运行原模型 f 与代理 g ，比较分数误差或决策一致率。取非负样本权重 w_i ，标量分数的加权均方误差可以写为

$$\hat{E}_{\text{fid}} = \frac{\sum_i w_i [f(\mathbf{x}_i) - g(\mathbf{x}_i)]^2}{\sum_i w_i}, \quad \sum_i w_i > 0.$$

整体评价的样本与权重对应声明的参考范围，局部评价则对应当前输入的邻域。若解释只声称复述类别，就报告预测类别一致的比例；若声称复述概率，类别一致仍不足以检验分数误差。按重要业务类型分别计算，可以发现总体误差掩盖的分支。

对特征归因，要将“贡献分配是否满足其定义”和“是否预测干预效果”分开。积分梯度的贡献和应接近基准分数差，SHAP 应符合声明的背景和特征缺失规则；这些是计算一致性检查。若进一步主张高归因输入对输出更关键，可以按归因排序逐步删除高分部分，记录目标分数随删除比例的

变化，并与随机删除、低分部分先删除比较。反向实验从基准开始逐步插入高分部分，检查分数怎样恢复。删除、插入曲线及其曲线下面积给出相应扰动规则下的证据；并非所有满足分配公理的方法都应在任意删除规则下取得最优结果。

这类检验必须控制输入有效性和改动量。删除文字可能改变语义，遮挡图像可能产生异常块，需要与同样大小、同样替换方式的对照比较。既含支持也含反对证据时，应分别检查正负作用；不能把移除反对证据后分数升高误写成解释失败。对于部分依赖或概念作用摘要，可以在新的参考样本上重算曲线或概念敏感性，并检查重要差异是否复现。

Adebayo 等提出的显著性图健全性检验，直接检查解释是否依赖它声称解释的模型与数据。一类检验逐步随机化网络参数，观察解释是否改变；另一类在随机打乱标签后训练网络，再比较解释。如果一幅图在预测机制已经改变后仍几乎不变，它可能主要反映输入边缘或架构先验，不足以解释模型学到的输入输出关系。研究报告的失败针对被测试方法与设置，不能据此宣称所有显著性方法都无效¹⁴。

通过随机化检验只是排除一种明显错误。机制解释还应在新的输入配对上预测屏蔽、替换或恢复某组件后的变化，再与实际干预比较，并设置随机位置与等强度替换的对照。训练追溯则要挑选高影响、低影响及随机样本，通过小幅重新加权或部分重训练核对影响方向和大小；不能拿输入遮挡实验验证关于训练过程的论断。每类检验改变的对象不同，证据应与解释声称的作用对应。

模型生成的理由属于待检验输出。它可能概括了部分依据，也可能事后构造一个流畅理由。若模型在关键证据被替换后行为改变而理由保持不变，理由的忠实性就受到质疑。解释评价因此要连接模型行为，而不能只评价语言是否清晰。

15.4.2 完整性与覆盖范围

忠实地解释一小部分行为，仍可能遗漏使用者真正关心的部分。这里需要区分数值分配的完整与行为范围的覆盖。对具有加性完整性要求的归因，可以计算

$$e_{\text{sum}} = \left| f(\mathbf{x}) - f(\mathbf{x}_0) - \sum_j a_j \right|,$$

其中 a_j 为各项归因。积分梯度用这个残差检查数值积分，Shapley 归因则用其声明的 $v(\emptyset)$ 和 $v(N)$ 替换两端分数。Grad-CAM 并不承诺贡献和等于分数差，不应强行用这项标准判它失败。即使残差为零，也只表示所定义的数值差被分配完毕，未证明现实原因或全部内部通路已经解释清楚。

对整体代理或规则集，需要检验它能覆盖哪些输入和分支。可以预先划

¹⁴ J. Adebayo, J. Gilmer, M. Muelly, I. Goodfellow, M. Hardt, B. Kim, *Sanity Checks for Saliency Maps In* arXiv preprint arXiv:1810.03292, 2018

分语言、任务类型和重要错误情境，分别报告样本数、代理误差及规则能够给出解释的比例。若解释系统允许弃权，应同时报告有解释样本的质量与被覆盖比例，避免仅解释少数简单样本后宣称整体有效。测试集没有覆盖的区域，不能因为公式在该处也能计算就视为已经得到解释证据。

对机制解释，覆盖还包括相同现象是否在多个输入、不同表达和组合条件下成立。恢复某个位置可以支持一个局部机制假设；要概括一类行为，还需在新的输入配对上复测，并检查未被该机制解释的剩余效应。覆盖范围越大，需要承担的证据要求也越多。

15.4.3 解释的稳定性

稳定性要检验的是在解释目标保持相同的条件下，结论会不会因计算随机性或无关变化而剧烈改变。固定模型、输入、基准和解释定义，重复邻域采样、背景采样或概念方向拟合，可以测量方法本身的波动。对数值归因可报告各项均值与标准差，对重要因素排序可比较秩相关，对前 k 项集合可计算交集大小除以并集大小。方向或特征编号可交换时，需要先匹配再比较，不能将编号不同当作语义不一致。

另一种试验是施加预期不改变解释目标的轻微输入变换，再检查解释是否相应保持。图像平移后的作用区域需要先映射回同一坐标，词语改写也需要先对应解释单位。即使语义和最终输出相同，模型也可能改用了另一组依据；因此，解释差异需要结合模型响应检查，不能仅凭输出未变就认定解释不稳定。如果模型本来就越过决策边界，解释改变更可能恰好忠实，不能一律惩罚。固定模型时的计算稳定性、换用新输入时的适用性和重新训练模型后的复现性，应分别报告。

还需检查解释是否对不该忽略的变化作出反应。随机化模型后解释完全不变，可能说明解释不依赖模型，而不是稳定性很好。反之，两套实现若计算同一函数，而方法声称只解释输入输出关系，则应检查是否得到相容结论。这些比较都需要先规定什么应保持、什么应改变，避免把“永远输出同一张图”当成高质量解释。

15.4.4 可理解性

可理解性关注目标读者能否正确读懂解释。规则数量、树深度、非零归因数量和概念名称熟悉程度，可以作为理解负担的线索，但只是替代指标。一条很短却含义模糊的规则，可能比稍长的明确计算更难理解。

直接检验可以让参与者只凭解释预测模型对新输入的反应，回答改变某个条件后模型会怎样判断，或指出规则适用的范围。记录答案正确率、完成时间和系统性误解，并控制任务难度、提供的事实和读者背景。例如，给出示例 15.1 的规则后，让读者判断 $(0, 1)$ 是否会被隔离，能检查其是否

理解了加性分数与阈值；只问“这份解释清楚吗”，只能得到主观评价。

Doshi-Velez 与 Kim 区分了真实应用中的人员评价、简化任务中的人员评价，以及不用人员参与的替代指标。这一区分说明，规则数少、归因稀疏等便于测量的指标，需要额外证据才能代表实际理解¹⁵。

在理解测试中，可以让使用者判断模型会不会拦截一组新邮件，以模型的实际行为核对答案。这与判断邮件本身是否应该拦截不同：前者检验人能否理解模型，后者还依赖其对任务的判断。纠正误拦和减少错误采纳的效果，留待下一小节放入使用任务中评价。只询问“是否喜欢这份解释”，则主要测量主观感受，不能替代这两种任务结果。

实验还应避免让解释组额外获得原本就缺失的关键信息，而对照组没有相同机会。否则改善可能来自信息量，而不是解释结构。可以给两组相同事实，仅改变组织方式，或单独比较附加事实与解释方法的贡献。对于不同专业背景的使用者，适合的粒度也可能不同；面向开发者有效的激活图，未必能帮助邮件收件人作出正确决定。

15.4.5 使用有效性

读懂模型不等于更好地使用模型。使用有效性要检验解释是否帮助发现错误、减少错误采纳或选择复核，并核算增加的时间与认知负担。补救行动执行后的效果由第 15.5.3 节另行检验。因此，它需要把解释放回真实或足够接近真实的决策任务中。

可以比较无解释、所提解释与信息量相当的对照说明，让使用者处理同一难度的任务，记录最终决策损失、正确纠错比例、正确预测被无故否决的比例及用时。对同一人重复呈现同一题会带来记忆效应，设计时应随机分配题目或平衡呈现顺序。对存在模型错误的任务，还应单独报告错误建议被采纳的比例；总体采纳率提高可能只是过度信任。

例如，假设两个复核组各处理 100 封难度匹配的邮件，模型在各组都有 20 次错误。解释组纠正 15 次，但又把 8 个原本正确的判断改错；对照组纠正 10 次，只额外改错 1 次。最终错误数分别为 $20 - 15 + 8 = 13$ 和 $20 - 10 + 1 = 11$ 。这个教学例子说明，只报告解释组“纠错更多”会遗漏新的损害；需要比较最终结果，并用足够样本评估差异的不确定性。

五个维度应联合阅读：低代理误差提供忠实性证据，分组检查限定覆盖，重复试验测量稳定性，读者任务检验可理解性，实际决策对照检验使用收益。前一项通过不自动推出后一项；若因简化解释而放弃部分细节，应报告这种取舍落在哪些维度和输入范围中。

¹⁵ F. Doshi-Velez, B. Kim, *Towards A Rigorous Science of Interpretable Machine Learning* In arXiv preprint arXiv:1702.08608, 2017

15.5 决策的补救

知道邮件为什么被误拦后，使用者还需要知道怎样恢复正常业务。“不同结果的反事实比较”段给出了能够改变模型判断的输入，但从“另一输入会被放行”到“使用者能够完成补救”，还缺少行动及其后果。**决策补救** (recourse) 研究通过可行行动改变不利决策的办法；评价时还要检查这种改变是否符合实际任务目标。

本节围绕一份补救方案的形成与检验展开：先确定可以采取哪些行动、希望达到什么结果，再在行动约束下比较方案并选择，随后验证行动能否执行、后果是否符合预期、目标是否真正达到。这三个问题相互依赖。没有行动及其后果的描述，就无法判断约束下是否存在解；没有明确成本与目标，就无法比较哪种方案更好；求得最优解，也只说明它在所设模型中最优，仍需检验现实效果。

15.5.1 补救行动的确

补救先要明确谁能够做什么。对于被误拦的邮件，发送方可以纠正错误的来源信息、补充可核验的证明，或在保留业务内容的前提下改变附件形式；收件人可能只能请求复核；系统运营方则能够检查提取错误或调整处理流程。不同参与者拥有不同权限，不能把一方能够完成的操作直接推荐给另一方。

这些行动可以从三个方向寻找。数据记录错误时，应纠正记录，使系统依据真实信息重新判断；记录正确但当前状态不满足要求时，可以改变可行动的条件，例如补充证明或完成必要培训；预测或处理流程存在错误时，可以提交申诉、请求人工复核。前两类通常能表示为行动后得到新输入，再由系统重新判断；人工复核还涉及决策流程的变化，需要说明由谁处理、依据什么以及何时反馈，不能等同于某个模型分数下降。

确定目标也不能只写“让结果翻转”。正常邮件的目标是保留真实业务内容并得到恰当处理，单纯删除付款要求虽然可能使评分下降，却可能把原业务请求一并删除。算法输出改善与任务得到补救应分别定义。若目标是进入人工复核，就应检查是否确实进入复核流程，而不是要求模型立即给出有利类别。

把候选行动写成具体方案时，应列出执行者、操作对象、所需资源、完成时间和预期变化。例如，“改善附件”不足以执行；“由发送方将附件转换为不含可执行内容且保留必要信息的格式，再重新提交”才说明了行动。在这里，解释用于提出候选方案，任务知识与实际权限决定它们是否可以实施。

为后续比较，设当前状态为 $\mathbf{x}$ ，动作 a 实施后的状态由 $T(\mathbf{x}, a)$ 描述。 T 是行动后果模型：它说明执行动作后哪些字段会改变、改变多少，以及是

否带来其他变化。固定预测规则 $\hat{y}$ 时，候选结果为 $\hat{y}(T(\mathbf{x}, a))$ ；涉及人工复核等流程变更时，则需要另行描述流程结果。输入距离小不等于行动容易，直接改写记录也不等于改变了记录所描述的事实。

15.5.2 补救行为的选择

有了候选行动，还需要回答哪些能做、哪些值得做。不可改变的属性、操作权限、允许的变化方向和取值范围限定行动本身；费用、时间和业务内容的保留要求进一步限定行动后果。例如，附件必须保留合同信息、方案必须在截止时间前完成，都应作为筛选条件。必须满足的条件是硬约束，不能因为另一个方案分数更好就忽略；在可行方案之间偏好更少时间或更低费用，则属于优化目标。

设 $A(\mathbf{x})$ 为满足这些行动约束的集合， $c(a; \mathbf{x})$ 为执行成本， Y_{goal} 为目标输出集合。对于行动后仍由固定规则判断的情形，最低成本补救可以写为

$$\begin{aligned} \min_{a \in A(\mathbf{x})} \quad & c(a; \mathbf{x}) \\ \text{满足} \quad & \hat{y}(T(\mathbf{x}, a)) \in Y_{\text{goal}}. \end{aligned} \quad (15.11)$$

A 回答行动是否允许， T 描述行动会造成什么变化，目标约束检查变化后是否得到所需结果， c 用于比较达标方案。只有在目标约束下仍存在可行行动，才有相应的补救方案；其中成本最低者才是所设问题的最优解。这里的“最优”依赖行动范围、后果模型和成本定义，不表示对所有人、所有偏好都最好。

成本应反映实际负担，而不是直接相加不同单位的特征差。例如，时间、费用和操作次数可以分别报告；确需合为一个数时，应说明权重及其依据。若使用者对时间和费用有不同偏好，可以提供若干互不支配的方案，即不存在另一方案在所有所考虑的成本上都不更差、且至少一项更好，再由使用者选择。约束改变也可能改变最优方案，不能脱离可用资源推荐统一的“最小改动”。

Ustun 等把可行动变量、变化方向、离散取值和成本写入线性分类器的补救问题，用整数规划搜索满足目标分类约束的行动，并评估哪些个体缺少可行补救。这类工作把输入层面的目标变化落实为可以检查和优化的行动条件¹⁶。

实际求解取决于行动如何表示。候选方案较少时，可以逐项计算后果、筛除不满足约束者，再比较成本；连续与离散操作并存时，可以在适用的模型形式下使用数学规划或搜索。找到一个可行方案只证明存在这样的方案，有限搜索失败也不能自动证明无解。声称全局最优需要相应的搜索完备性或最优性证据，否则应说明得到的是当前搜索范围内的候选。

行动后果之间还可能存在依赖。培训增加技能，也占用工作时间，进而

¹⁶ B. Ustun, A. Spangher, Y. Liu, *Actionable Recourse in Linear Classification* In Proceedings of the Conference on Fairness, Accountability, and Transparency, 2019

影响当期资源；优化器不能把这些变化独立设定。Karimi 等提出在结构因果模型中计算干预后果，再在行动空间选择低成本干预。此时，改变一个变量还会按照结构方程影响其后继变量，区别于在输入表中独立修改多个字段¹⁷。

示例 15.3 约束与成本决定补救方案 设一个教学模型仅在 $s+r \geq 3$ 时批准某项申请，其中 s 为技能分数， r 为当期资源指标，当前状态为 $(1, 1)$ 。若只在输入表中把 s 改为 2，就能越过边界；但假设培训强度 $a \geq 0$ 带来的实际变化是 $s' = 1 + a$ 、 $r' = 1 - a/2$ ，则总分为 $2 + a/2$ ，需要 $a \geq 2$ 。如果培训上限为 $a \leq 1$ ，仅靠培训就没有可行补救。

再假设可以获得强度为 b 的资源支持， $0 \leq b \leq 1$ ，使 $r' = 1 - a/2 + b$ 。允许组合两种行动，教学成本定义为 $c(a, b) = a + 3b$ ，则目标条件变成 $a/2 + b \geq 1$ 。单独使用资源支持 $(a, b) = (0, 1)$ 可达标，成本为 3；组合方案 $(1, 1/2)$ 也可达标，成本为 2.5。

组合方案在上述假设下确实最优：任何可行解都满足 $b \geq 1 - a/2$ ，因此 $c(a, b) \geq 3 - a/2 \geq 2.5$ ，而 $(1, 1/2)$ 恰好达到该下界。若总预算进一步限定为 2，则两种行动及其组合都无法在该预算下完成补救。这个结论依赖明确的行动范围和后果方程，而不是因为一次搜索没有找到方案。

图 15.5 将输入表中的变化与行动造成的变化并列。补救是否可行，要同时检查后果、权限和预算，不能只看模型输出是否翻转。

若行动后果或未来模型不确定，可以要求方案在声明的一组情形下都有效，或在明确的概率模型下以足够高的概率达标。更严格的要求可能增加成本或使可行集合为空，应同时报告这种取舍。没有可行方案时，需要说明阻碍来自预算、权限、行动后果还是决策规则，并考虑复核或流程调整，不能要求使用者实施本就不可能的改动。

15.5.3 补救效果的验证

优化得到的方案需要经过两层验证：在计算模型中确实满足约束和目标，以及在实际执行中产生了预期结果。前者核对求解是否正确，后者检验行动后果模型是否可信。第 15.4.5 节评价提供解释是否帮助人作出判断，本小节则评价执行补救行动后发生了什么，二者不能用同一项主观满意度代替。

方案与约束的复核 对候选方案重新检查执行权限、不可变属性、变量取值、时间和预算，再按所声明的 T 生成新状态，通过完整的特征处理与决

¹⁷ A.-H. Karimi, B. Schölkopf, I. Valera, *Algorithmic Recourse: from Counterfactual Explanations to Interventions* In Proceedings of the 2021 ACM Conference on Fairness, Accountability, and Transparency, 2021




图 15.5 示例 15.3 的行动路径。虚线只修改技能记录；实线培训 $a = 1$ 使 (s, r) 从 $(1, 1)$ 变成 $(2, 1/2)$ ，再由支持 $b = 1/2$ 到达批准边界。仅培训且 $a \leq 1$ 无法达标，组合成本为 2.5；预算收紧为 2 时没有可行补救。

策流程重新计算结果。若求解时使用了代理模型或连续近似，必须回到实际系统复核，而不能只检查代理分数。成本最优性也应与可行性分开：可以用穷举、小规模精确求解或求解器提供的有效界限比较成本；无法证明最优时，应报告这一限制。

在示例 15.3 中，代入 $(a, b) = (1, 1/2)$ 得到 $(s', r') = (2, 1)$ ，总分为 3、成本为 2.5，且满足两项行动上限。这验证了方案在教学模型中的可行性和达标性；前面的成本下界则另行证明最优性。若实际预算为 2，同一方案即使能够达标，也不再可执行。

行动后果与实际收益的检验 实际验证需要记录行动是否完成、实际花费多少、状态如何变化，以及最终决策是否达到目标。用实际新状态与 T 的预测作比较，才能发现后果模型是否高估了行动效果。只观察到技能与资源相关，通常不足以判断某个人培训后的变化；未观测因素和具体实施方式都会影响建议。可以结合已有干预证据、适当的对照研究或实际执行记录复核后果假设，并明确它们能支持的范围。

沿用同一例子，若实际每单位培训消耗的资源为 0.8 而非假设的 0.5，那么执行 $(1, 1/2)$ 后状态为 $(2, 0.7)$ ，总分只有 2.7，目标没有达到。求解器并未算错；失效来自行动后果模型。应据此修正后果估计并重新选择方案，而不能把纸面上的最优性当作实际有效性的证明。

评估一套补救方法时，应分别报告有可行建议的比例、建议被实际完成

的比例、完成后达到目标的比例，以及实际成本和不利后果。每项比例都要说明分母；只在成功执行者中统计达标率，会漏掉没有方案或无法执行的人。若要声称建议本身改善了结果，还需与无建议或既有处理方式作适当对照，处理参与者自选择等差异，不能只比较执行前后的变化。

目标结果之外还要复核任务是否完成。邮件获得放行但合同内容被破坏，或模型评分降低却没有消除真实风险，都不能算完整补救。对于复核与申诉，应检查是否得到实质处理、原有错误是否纠正，以及耗时是否可接受。无论采用哪条路径，都要把决策变化与实际收益分别记录。

效果保持与失效处理 行动往往需要时间。方案应注明依据的模型版本、后果假设和有效条件；执行周期较长时，需要检查模型更新、环境变化或后果估计误差是否会使它失效。可以在一组有依据的情形下重新计算达标与成本，或跟踪执行后的结果，但有限情形测试不能自动给出所有未来条件下的保证。

验证失败后应定位缺口：操作无法完成就修订行动集合，实际状态变化不符就修订后果模型，模型或流程变化则需要重新评估目标条件。三小节由此形成闭环：行动确定提供候选，约束优化选出方案，效果验证检验其依据并指导修订。某些个体最终仍可能没有可行补救，应明确说明限制和可用的复核途径。

15.6 前沿研究

基础模型把解释对象扩展到高维内部表示和长行为过程。除了找到可读的模式，还需检验这些模式能否重复发现，以及局部解释能否连接成对完整行为的说明。

15.6.1 从神经元到可检验的特征

基础模型中的机制解释尝试从高维激活提取较可读的特征，再分析特征如何参与计算。直接给单个神经元命名往往不够，因为一个坐标可能对多种不相关情境响应，一种语义也可能分布在多个坐标。稀疏自编码器用一组数量更多的字典方向重构激活，并要求每个输入只使用少量方向。对激活 $\mathbf{h}$ 、稀疏编码 $\mathbf{z} = E(\mathbf{h})$ 、字典矩阵 $\mathbf{D}$ 和偏置 $\mathbf{b}$ ，一个基本目标为

$$\min_{E, \mathbf{D}, \mathbf{b}} \mathbb{E}_{\mathbf{h}} [\|\mathbf{h} - \mathbf{D}E(\mathbf{h}) - \mathbf{b}\|_2^2 + \lambda \|E(\mathbf{h})\|_1], \quad (15.12)$$

并约束字典列的尺度，以免单纯放大字典、缩小编码来规避稀疏惩罚。重构项保留信息，稀疏项鼓励分开少数激活因素，但两者都没有直接保证人能够命名这些因素。

Bricken 等在单层语言模型中研究了这种字典分解，并结合高激活样本与特征干预分析解释。相比按神经元检查，它允许语义方向偏离原始坐标轴；相应代价是字典宽度、稀疏程度、重构误差和特征拆分方式都需要选择。某个方向在若干样本上看似对应“危险内容”，不能因此把它当成完整的安全判别器¹⁸。。

15.6.2 特征解释的可复现性

Song 等研究稀疏自编码器在重复训练中的特征一致性，并提出在重构与稀疏性之外增加一致性评价。该结果把“发现了可读特征”推进到“发现是否能够复现”，但跨运行一致仍不单独证明特征具有现实因果意义或覆盖模型全部行为¹⁹。。

一致性评价需要区分特征置换与实质分歧：两次运行中的同一语义可能对应不同编号，需要先匹配方向或激活模式；一个宽泛特征也可能在另一次训练中被拆成多个细粒度特征。可读性、重构质量、重复运行匹配和干预效果应共同报告，任何一个指标都不能单独代表机制解释已经完成。将解释用于第 14.2 节的行为监督时，还需验证解释特征能否预测新的失败，而不是只复述已检查案例。

15.6.3 跨步骤的行为依赖

除了在重复训练中得到相近特征，长行为序列还需要解释跨步骤的依赖：局部合理的工具选择可能组合成失败。单次归因难以表达累积关系，需要结合机制干预与行为测试检验解释。

以邮件助手为例，误拦可能来自错误读取附件，也可能来自后续工具结果覆盖了原有证据。解释系统应明确时间顺序，区分读取到信息、在表示中保留信息和实际据此选择动作。若只对最终拒绝语句作归因，前面的错误状态可能已经不可见。面向这类任务，解释的目标将从一张静态贡献图扩展为可反复检验的行为依赖说明，同时保留干预本身的范围与限制。

15.7 本章小结

对章首的误拦邮件，整体解释给出一组邮件上的规则与依据，单次解释则定位这一封邮件的判断。基于模型结构的解释交代计算规则，基于输入的解释比较字段或区域的作用，基于语义的解释检查这些依据对应的含义。三个方面相互联系，能够共同描述模型在所声明范围内怎样作出判断。

对一次判断，推理输入、推理计算过程和训练数据提供了三个互补的解释角度。相似案例、反事实、局部代理与特征归因共同研究固定模型对输入的响应；内部干预检验预测过程中的计算作用；训练数据追溯则研究学习经历如何影响当前结果。能够复算一份贡献，不代表已经找到内部机制；

¹⁸ T. Bricken, A. Templeton, J. Batson, B. Chen, A. Jermyn, T. Conerly, N. Turner, C. Anil, C. Denison, A. Askell, R. Lasenby, Y. Wu, S. Kravec, N. Schiefer, T. Maxwell, N. Joseph, Z. Hatfield-Dodds, A. Tamkin, K. Nguyen, B. McLean, J. E. Burke, T. Hume, S. Carter, T. Henighan, C. Olah, *Towards Monosemanticity: Decomposing Language Models With Dictionary Learning In Transformer Circuits Thread*, 2023

¹⁹ X. Song, A. Muhamed, Y. Zheng, L. Kong, Z. Tang, M. T. Diab, V. Smith, K. Zhang, *Mechanistic Interpretability Should Prioritize Feature Consistency in Sparse Autoencoders In Proceedings of the 64th Annual Meeting of the Association for Computational Linguistics*, 2026, pp. 2172–2210

找到一条内部通路，也不代表已经说明现实因果关系。把多个单次结论提升为整体主张，还需明确汇总规则、异质性和样本覆盖。

解释质量由忠实性、完整性与覆盖、稳定性、可理解性和使用有效性共同约束，应与论断对应的试验分别检验。即使这些检查通过，从“输入改变会改变输出”到“采取行动能够补救”，仍需可行动作与后果模型。解释清晰不代表模型正确，解释忠实也不代表依据公平。解释还可能展示训练样本、私人特征或内部记忆；为了让行为可理解而提供更多信息，也需要确定这些信息可以向谁公开。下一章将讨论数据使用、模型发布与信息披露中的隐私保护。

延伸阅读 Doshi-Velez 与 Kim 关于解释评价的框架适合继续区分应用任务、简化人员实验和替代指标；Ribeiro 等人的 LIME 与 Sundararajan 等人的积分梯度则可用于对照局部代理和基准归因的不同论断²⁰。。

若关注解释能否转化为行动，可继续阅读 Wachter 等人的反事实解释与 Karimi 等人的因果补救。前者寻找能够改变模型输出的邻近输入，后者把行动后的连带变化纳入结构模型；两者的差别正落在“预测翻转”与“现实可行补救”之间²¹。。

²⁰ F. Doshi-Velez, B. Kim, *Towards A Rigorous Science of Interpretable Machine Learning* In arXiv preprint arXiv:1702.08608, 2017; M. T. Ribeiro, S. Singh, C. Guestrin, "Why Should I Trust You?": Explaining the Predictions of Any Classifier In arXiv preprint arXiv:1602.04938, 2016; M. Sundararajan, A. Taly, Q. Yan, *Axiomatic Attribution for Deep Networks* In Proceedings of the 34th International Conference on Machine Learning, 2017, pp. 3319–3328

²¹ S. Wachter, B. Mittelstadt, C. Russell, *Counterfactual Explanations without Opening the Black Box: Automated Decisions and the GDPR* In Harvard Journal of Law & Technology, 2018; A.-H. Karimi, B. Schölkopf, I. Valera, *Algorithmic Recourse: from Counterfactual Explanations to Interventions* In Proceedings of the 2021 ACM Conference on Fairness, Accountability, and Transparency, 2021

隐私保护

为了检验邮件分类器对不同群体是否公平，开发者可能需要收集额外属性；为了提高识别能力，又可能希望使用私人邮件训练。模型发布后，即使原始邮件没有公开，输出和参数仍可能透露训练信息。数据后来被撤回时，删除存储中的记录也未必消除已经学入模型的影响。

在第 10 章的三层架构中，隐私保护主要属于系统属性或规范要求层：它规定谁的哪些信息可以被哪些主体以何种方式使用或获知。泄露审计、形式化分析与实现核查位于证据能力层；访问授权、数据流控制、重复发布的隐私会计和撤回处置，则需要在威胁与生命周期治理层落实。

要说明系统是否保护了隐私，需要先界定受保护的人、私人事实和泄露渠道，再确定可用什么证据检查这些边界。验证由此分为可见结果的泄露检验与处理过程的核查。保护措施按采集、训练和发布使用三个阶段安排；当数据使用许可被撤回时，还需分别处理数据副本与已进入模型的影响。公平审计中的群体越细，可能越容易发现集中伤害，也越容易暴露少量成员的信息；解决办法需要同时保留审计所需的证据，并约束信息可见范围，不能单独追求更细的统计或更少的数据。

16.1 隐私保护的基本概念

16.1.1 保护对象与保护范围

机器学习中的**隐私保护**（privacy protection）关注在完成任务时，如何限制个人信息被不适当访问、使用、推断或披露。保护对象不仅是提供训练数据的人，也包括正在提交请求的使用者，以及出现在邮件、图片或对话中的第三方。例如，用户提交一封邮件，邮件可能同时包含发送者、收件人和其他联系人的信息；确认提交者有权使用某个接口，并不能自动确定全部内容可以向谁公开。

需要保密的事实与保护单位应分别说明。这里的“秘密”是观察者试图获知的事实，例如“这封邮件参加过训练”、邮件里的私人编号，或推理请求中的地址。保护单位规定一次比较中允许改变多少数据，例如一条记

录或一个用户的全部记录。换言之，秘密回答“要保护什么”，保护单位回答“机制限制谁的数据对结果的影响”，二者不是同一种分类。对单封邮件提供保护，不自动等于对同一用户一万封邮件提供同样强度的保护。

第 13 章用于比较误差的群体是评价单位，这里按记录或按用户界定的对象是保护单位；按群体报告效用损失，并不等于已经对整个群体建立同强度的隐私保证。还应说明同一个人的数据怎样被归集，以及记录中共同出现的其他人是否被所选单位覆盖，不能只按账户所有者命名保护对象。

以下沿用一個受控例子：用户的一封邮件 z 含有私人项目编号，系统用一批邮件 D 训练分类器，并向外提供查询接口。需要分别考虑查询者能否判断 z 参加过训练、模型能否复现编号，以及训练服务器能否从共享更新恢复邮件。若该用户后来撤回全部邮件，删除范围还需要从单条 z 扩展为能定位到的全部相关记录及其衍生状态。

一项可核查的承诺应同时说明受保护对象、私人事实、使用目的、允许接收者和覆盖的系统接口。例如，允许模型为收件人整理邮件，不表示允许模型把其中的地址发送给无关工具。隐私保护应围绕这些边界展开，而不能只问训练数据是否曾经公开。

16.1.2 机器学习中的泄露途径

泄露可以发生在信息流的多个位置。采集、传输和存储阶段可能直接暴露原文；训练阶段可能通过梯度、检查点或调试日志暴露样本；模型发布后，参数和查询接口可能透露训练信息；推理时新加入的私人上下文，又可能流入检索结果、工具调用、回复和服务日志。调查时应逐处标明谁能够观察什么，不能只检查最终回答。

成员推断 (membership inference) 试图区分某条记录是否参与训练；属性推断利用可见信息推测未公开字段；数据重构尝试恢复输入内容；内容提取则可能通过多次查询诱导模型复现训练片段。这些名称描述泄露的私人事实或恢复方式，并不对应互不相干的处理阶段。例如，训练更新可以被用于重构，发布模型既可能被用于成员推断，也可能被用于内容提取。

模型并不需要逐字保存原文才可能泄露。对训练成员和非成员给出不同的分数模式，已经可能提供成员身份的线索；共同训练得到的参数也可能保留罕见片段。相反，模型正确判断一封邮件属于某类，可能只依靠一般语言规律，不能仅凭预测准确便认定它记住了该邮件。验证时要区分公开规律、观察者原有知识和使用私人数据后新增的信息。

训练数据本地保存只限制了原始数据的直接流转。如果参与者仍发布可逆的梯度或包含记忆的模型，信息可能从其他渠道流出。将原文换成向量、梯度或统计量改变了信息的表示，却没有自动建立保密性。访问权限、计算中间状态的可见性与最终结果所包含的信息，需要分别检查。

推理阶段的泄露也可能不涉及训练记忆。若用户刚提交的私人编号被模型转交给不应接收它的工具，即使模型从未用该编号训练，也已经越过了所声明的信息边界。一段内容出现在公开网页上，也不表示它适合在任何使用情境中再次披露。具体目的与接收范围仍需在第 10.1 节定义的情境中确定。

16.1.3 保护承诺与强度

对于直接访问，可以规定谁能够读取明文、执行哪些操作；对于共享计算，可以限制参与者看见哪些中间状态。但获准看见的统计量或模型仍可能透露私人事实，因此还需要约束发布结果对受保护对象的依赖。下面的差分隐私用于表达后一类承诺，并不替代全部访问与使用要求。

访问控制规定谁可以查询，却还没有说明获准查询者会知道多少。例如，某人已知除 z 以外的所有邮件，系统又发布包含某关键词的准确邮件数。若 z 含有该词，其加入就把计数从 c 变成 $c + 1$ ，查询者可以完全区分这两种情况。把结果称为“统计量”并没有消除单条记录的影响。

输出保护的一种思路是限制单个受保护对象对发布结果的影响。如果某个用户是否参与都只会小幅改变输出分布，攻击者就难以仅凭该变化确定其参与情况。**差分隐私** (differential privacy, DP) 将这种要求写成对相邻数据集的比较。

定义 16.1 差分隐私 给定相邻关系 $D \simeq D'$ 。若随机算法 M 对所有相邻数据集和所有可测输出事件 E 均满足

$$\mathbb{P}(M(D) \in E) \leq e^\epsilon \mathbb{P}(M(D') \in E) + \delta, \quad (16.1)$$

则称其满足 (ϵ, δ) 差分隐私。这里 $\epsilon \geq 0$, $\delta \in [0, 1)$ ，概率来自算法的随机性。

回到计数例子，令 D 包含 z ， D' 不包含 z ，并取输出事件 $E = \{c + 1\}$ 。若发布准确计数，则定义左侧为 1、右侧为 δ ，在 $\delta < 1$ 时不能成立。机制因此需要让两种数据下的可能输出有足够重叠，例如适当随机化发布值。定义只说明重叠需要达到什么程度，并未指定必须用哪一种加噪算法；机制负责实现定义，验证负责核对实现和证据。

相邻关系可以定义为增加或删除一条记录，也可以定义为替换一条记录；用户级保护则比较相差一个用户全部记录的数据集。选择相邻关系就是选择保护单位。较小的 ϵ 和 δ 限制更强，但 δ 不是“每个用户以该概率被完全公开”的简单解释。

差分隐私限制参与数据带来的额外信息，并不阻止利用公开规律作出人口层面的推断。如果所有同类人群都具有某个属性，即使没有使用某个

人的数据，也可能推测其属性。它也不保证任务输出正确。隐私定义、机制和组合分析需要一起理解¹。

当 $\delta = 0$ 时，定义还可以通过假设检验理解。设 D 和 D' 只相差某条记录，检验在看到输出后决定“该记录参加了训练”，并把作出这一决定的输出集合记为 E 。在固定的这对数据集上，真阳性率 $t = \mathbb{P}(M(D) \in E)$ 与假阳性率 $f = \mathbb{P}(M(D') \in E)$ 满足 $t \leq e^\epsilon f$ ；近似差分隐私则给出 $t \leq e^\epsilon f + \delta$ 。这说明保证约束的是整条可行检验边界，而不是某个已知攻击的平均正确率。反向比较也受相邻关系的对称性约束。

保护单位扩大时，承诺会变弱。若两个数据集相差 k 条记录，可以在它们之间插入 $k - 1$ 个中间数据集，逐次应用定义。由此得到

$$\mathbb{P}(M(D) \in E) \leq e^{k\epsilon} \mathbb{P}(M(D') \in E) + \delta \sum_{j=0}^{k-1} e^{j\epsilon}. \quad (16.2)$$

这个推导表明，记录级保护可以推出群体界，却通常不能保持原来的参数。若一名用户最多贡献一百封邮件，直接把记录级 ϵ 称为用户级 ϵ ，会隐藏至多一百次相邻变化。限制每人贡献数量或直接按用户裁剪，才会改变需要分析的敏感度。

观察者与信任边界 经典的中心化差分隐私允许可信的数据管理者先读取原始数据，再发布私有结果。若用户不愿让管理者看到明文，可以在发送之前就随机化信息，这称为**本地差分隐私** (local differential privacy)：任意两个可能的用户输入，都应产生难以区分的消息分布。它把保护放到数据离开用户的一刻，但每个用户独立加入的噪声需要共同进入统计估计。本地与中心化的区别在于谁可以接触明文；两者都可以采用差分隐私来约束指定接口的输出影响，不是两种互相排斥的隐私目标。具体的发送机制在第 16.3.1 节展开。

16.2 隐私保护的验证

确认泄露与证明保护成立，需要不同证据。从结果上检验，是让观察者在规定权限下尝试获得私人事实；这里的结果包括回复、分数、参数和可见更新，不仅是最终文本。从过程上核查，是检查信息如何流动，以及访问控制、随机机制和发布步骤是否满足承诺。结果检验可以揭示实际泄露，过程核查可以发现尚未被攻击利用的缺口；形式化保证还需要覆盖所有允许输入的论证。下面按这两类证据组织方法，再说明验证结论可以支持到什么程度。

¹ C. Dwork, A. Roth, *The Algorithmic Foundations of Differential Privacy* In Foundations and Trends in Theoretical Computer Science, 2014, vol. 9, no. 3–4, pp. 211–407

16.2.1 基于可见结果的泄露检验

经验审计可以使用属性推断、成员推断、重构和提取攻击寻找泄露。审计必须固定攻击知识、查询预算、先验和评价数据，并区分随机猜测、总体规律与记录特有信息。如果成员和非成员来自不同时间或来源，攻击可能只识别了分布差异，未必识别训练成员身份。

审计方法应由秘密和可见接口共同选择：若秘密是未公开属性，就比较模型输出带来的额外推断能力；若秘密是某条记录是否参加训练，就检验成员身份；若关心发布模型能否复现私有内容，就尝试内容提取；若训练时共享更新，则检查更新是否足以重构输入。以下审计都要报告所恢复的信息、所需权限、误报及查询成本，而不能只报告一个含义不明的攻击成功率。

原文与字段的直接暴露 有些泄露不需要复杂攻击：系统可能把邮件地址写入公开日志，或把工具无需接收的私人编号直接放进请求。可在隔离测试中使用合成私人标记，记录输入、模型回复、工具参数和可访问日志，逐项核对标记到达了哪些接收者。测试应涵盖不同账户权限和处理分支，并预先说明哪些流转是允许的。发现标记越过边界，可以确认这条路径存在泄露；没有发现，则只覆盖已经检查的路径。这类检查验证信息是否被直接交付，下面的攻击审计进一步检查没有直接交付原文时能否推断或恢复秘密。

未公开属性的推断 若秘密是某个未公开字段，审计要检查模型输出是否让观察者比只使用其原有信息更容易推断该字段。例如，攻击者已经知道邮件主题和发送时间，希望推断未公开的项目类别；应分别训练只使用这些已知信息的基线，以及额外读取模型分数或表示的攻击器，再在同一来源的独立样本上比较。目标属性、攻击者先验、可见接口和查询预算必须固定，否则较高准确率可能只来自总体中某一类别本来就占多数。

这种比较得到的是接口是否增加属性推断能力的证据。即使模型从未见过目标个人的记录，人口层面的相关规律也可能支持推断；反过来，攻击器没有超过基线，只说明当前知识和预算下没有发现额外信息。报告应同时给出基线、各属性取值的错误、罕见群体表现和概率质量，而不能把一个平均准确率直接解释为私人属性已经暴露或得到保护。差分隐私限制参与数据带来的额外影响，不会自动消除从公开规律得到的属性推断。

训练成员身份的判别 模型常对训练样本给出更低损失，但不同样本本来就有不同难度，不能用同一个置信度阈值充分区分成员与非成员。Shokri等人的工作使用影子模型模拟目标训练过程：在成员身份已知的辅助数据上训练模型，再学习其成员与非成员输出模式之间的差别。该工作说明，

只有查询权限也可能得到成员证据；它并不要求攻击者直接读取目标训练集²。

在有授权的受控审计中，可以把流程落实为以下步骤：

1. 从同一来源准备候选数据，保存哪些样本实际进入目标训练集；将用于训练攻击器的数据与最终评价攻击的数据分开。
2. 在辅助数据上训练影子模型，记录已知成员和非成员的损失、预测概率等输出特征，以成员标记训练攻击器。
3. 对目标模型查询相同类型的特征。用验证数据确定攻击阈值，再在独立审计集上分别统计成员命中率与非成员误报率。
4. 在固定查询预算下比较攻击器与不使用目标输出的基准，并报告低假阳性区域、候选成员先验和敏感子群的结果。

这套流程把模型输出变成可验证的身份判断，而不是把某条记录的高置信度直接解释为训练记忆。

图 16.1 将候选记录、可见查询输出与成员判定分开。目标成员真值只在受控审计中用于核验；攻击器可以在辅助数据上学习规律，却不会因此得到目标训练集的成员名单。




图 16.1 受控成员推断审计。本示意的成员与非成员候选按同一分布抽取，目标模型仅以训练集 D 训练；候选记录 $z = (\mathbf{x}, y)$ 通过获准接口取得输出。记录图标数量只表示分组，不代表成员先验。若真实标签 y 已知，可据此计算损失；输出向量旁的柱形仅作图标，不代表实测概率。攻击器由辅助成员数据训练，在验证数据上确定阈值后，到独立审计集统计成员命中率与非成员误报率。目标成员标记 m 只用于核验，不是攻击器输入。流程不保证攻击成功，权限、查询预算与成员先验须同时报告。

影子模型能够代表目标模型到什么程度，是这种审计的关键条件。若目标训练使用了不同的数据增强、早停或分布，辅助模型中学到的差别未必

² R. Shokri, M. Stronati, C. Song, V. Shmatikov, *Membership Inference Attacks against Machine Learning Models* In 2017 IEEE Symposium on Security and Privacy, 2017

迁移。一个准确率较低的攻击也可能只针对少量异常敏感记录成功，因此总体平均值需要与个体、类别和低假阳性区域的结果一起报告。

Carlini 等人的**似然比攻击**（Likelihood Ratio Attack, LiRA）将比较细化到单个待检验样本：用辅助训练估计“包含该样本”和“不包含该样本”时分数的分布，再比较目标分数更支持哪个假设。其研究强调在很低的假阳性率下报告真阳性率，并分析用变换后的置信度拟合分布的做法³。

设样本 z 的观测分数为 s ，两个假设下的密度为 $p_{\text{in}}(s | z)$ 和 $p_{\text{out}}(s | z)$ 。理想化的检验统计量为

$$\Lambda_z(s) = \frac{p_{\text{in}}(s | z)}{p_{\text{out}}(s | z)}. \quad (16.3)$$

对两个完全指定的简单假设，似然比检验在给定假阳性约束下具有最优检验功效；但实际审计只拿到有限辅助模型，密度估计有误差。该最优性不能直接变成经验攻击的无条件最优保证。逐样本比较的作用，是把“这条记录本来就容易预测”与“参与训练额外提高了它的可预测性”尽量分开。例如，同样观测到 0.95 的预测概率，对一条在“参加”和“未参加”两种情况下都容易预测的邮件，似然比可能接近 1；对一条只有参加训练才经常获得该分数的罕见邮件，似然比才可能显著大于 1。因此，影子模型攻击提供学习成员规律的一般流程，LiRA 进一步规定了逐记录比较两种假设的方法，两者不应当作为完全无关的攻击类别理解。

示例 16.2 成员先验改变结果的含义 假设候选记录中只有 1% 真正参加训练，一个审计检验的真阳性率为 0.8、假阳性率为 0.1。在一万条候选记录中，期望有 80 条真实成员被检出，同时有 990 条非成员被误报。检验报出的成员中只有约 7.5% 是真的。这个教学例子说明，在成员与非成员各占一半的测试集上表现尚可，不代表在实际低先验场景中具有同样可信的阳性结果。

发布模型中的内容提取 成员身份是一个二元事实，恢复内容则涉及更丰富的信息。Carlini 等人研究了从语言模型输出中提取训练序列，区分了模型对文本赋予高概率与实际能够通过查询提取文本。其对 GPT-2 的实验表明，模型发布后可能复现训练片段，且不能只用平均泛化误差判断这种风险⁴。

提取审计必须把“生成了一个常见句子”与“恢复了训练中特有内容”分开。可以在受控训练中加入来源明确的合成标记，观察是否被重新生成；真实数据审计则需要来源核对、去重和对照语料。前者便于比较不同机制，却未必代表自然数据中的记忆；后者更贴近实际，但来源不完整时容易把公开重合、猜测与真正的训练信息混为一谈。测试报告应保留这些不同的证据强度。

³ N. Carlini, S. Chien, M. Nasr, S. Song, A. Terzis, F. Tramer, *Membership Inference Attacks From First Principles* In arXiv preprint arXiv:2112.03570, 2022

⁴ N. Carlini, F. Tramer, E. Wallace, M. Jagielski, A. Herbert-Voss, K. Lee, A. Roberts, T. Brown, D. Song, U. Erlingsson, A. Oprea, C. Raffel, *Extracting Training Data from Large Language Models* In 30th USENIX Security Symposium, 2021

对受控邮件例子，可以在训练前生成不含真实个人信息的唯一项目编号，把它只放入指定邮件，并保存不含该编号的对照语料。训练后预先固定一组提示、解码方式和每次完整试验的查询预算 k ，保存所有输出，统计一次试验内准确复现编号的次数。若采用随机解码，可在相同条件下用独立随机种子重复完整试验，再用至少复现一次的试验数除以总试验数，估计该预算下的提取成功率；确定性查询过程只报告其实际结果，不把重复相同输出当成新增证据。同时以未训练该邮件的模型或相应对照训练作为比较。若允许自适应修改提示，修改所用的查询也计入预算。这样得到的是指定查询策略下的可提取性，而非模型内部是否保存了该信息的完整判定。后续遗忘审计可以复用相同提示和预算，直接比较删除前后及重训练参照。

共享更新中的输入重构 信息还可能在训练途中流出。Zhu 等人的梯度深度泄露 (Deep Leakage from Gradients, DLG) 研究了已知模型和共享梯度条件下的数据重构：寻找能够产生相似梯度的候选输入与标签。其意义在于指出梯度仍是与私人样本相关的观测，而不是天然匿名的摘要；论文中的重构效果依赖模型、批次和所共享梯度等实验条件⁵。

以平方损失的线性模型作一个简化说明。单条记录的损失为 $\ell = \frac{1}{2}(\mathbf{w}^\top \mathbf{x} - y)^2$ ，则梯度为 $(\mathbf{w}^\top \mathbf{x} - y)\mathbf{x}$ 。当残差非零时，即使未知其数值，梯度已经给出关于 $\mathbf{x}$ 方向的约束；若额外共享偏置梯度，信息还会增加。这不是任意模型都能精确重构的证明，却足以解释“没有传原文”为什么不能推出“没有传原文的信息”。保护必须作用于实际可见的更新，而不能只检查网络请求中是否包含原始字段。

实际重构审计需要在受控数据上保留真实输入作为参照，并固定攻击者已知的模型、更新轮次、批次大小和辅助信息。评价应比较重构内容与真实输入，也与仅凭公开先验作出的猜测比较：图像外观相近、文本主题相近和精确恢复私人字段，是不同强度的结果。若攻击只恢复了常见结构，不能据此声称重构了特定记录；若少量私人字段已经准确恢复，也不能因整体重构误差较大而忽略泄露。

16.2.2 基于数据流与实现的过程核查

核查过程时，需要把承诺落实为数据流和执行条件。对于直接访问，检查实际采集字段、身份与权限校验、存储副本、日志、检索接口和工具接收者；对于统计保护，检查发布程序是否满足形式化机制的前提。前者能够发现原文绕过保护接口流出的路径，后者检查已获准发布的信息是否受到所声明的约束。

可以给同一封邮件建立处理清单：输入进入哪些存储位置，哪些人员或服务能读取它，经过什么变换，又产生哪些中间状态和外部输出。结合配

⁵ L. Zhu, Z. Liu, S. Han, *Deep Leakage from Gradients* In *Advances in Neural Information Processing Systems*, 2019

置、实现和受控执行记录，检查拒绝访问是否实际生效、日志是否保留原文，以及备份和调试接口是否受到相同限制。仅审查一张流程图不足以确认运行中的程序遵守了这些约定。

验证差分隐私需要逐项核查保护单位、敏感度、噪声分布、抽样方式和组合过程。敏感度指改变一个保护单位能够使待发布统计量发生的最大变化，它决定需要多大的噪声。一个实现即使调用了“加噪声”函数，也不说明噪声已经按正确单位校准。例如，先按记录裁剪，却用用户级含义解释参数，会遗漏一个用户多条记录共同造成的影响。

参数选择、早停、超参数搜索和发布中间结果同样可能使用敏感数据。若这些环节没有被包含在分析中，最终模型的保证就可能不成立。实现检查还要覆盖随机数、日志和其他发布渠道；对一部分输出的证明不能自动覆盖系统另外写出的原始数据。

可把一次实现核验落实到同一个计数服务。若承诺是对增加或删除一封邮件提供纯 ϵ 差分隐私，程序应先把每封邮件对关键词计数的贡献限定为 0 或 1，再按敏感度 1 校准发布噪声，并记录同一数据还产生了哪些发布。这里不是仅核对配置文件里的 ϵ ，而是沿着“原始输入如何变成计数、计数如何变成输出”核对每一步。

例如，一封邮件内重复出现关键词一百次，如果程序按词频累计，单条贡献就可能为 100，原来的敏感度 1 论证不再适用。若仍按原尺度加噪，即使输出肉眼看来很随机，也没有实现所声明的保护。单元测试可以检查贡献截断、实际噪声尺度和重复发布记录，数学分析则需要覆盖所有允许输入；对几个样例测试通过不能替代敏感度的上界证明。第 16.3.3 节将给出对应发布机制及推导。

对于安全聚合或加密计算，验证对象则是规定参与者能够观察什么、允许哪些串通以及协议依赖什么条件。计算过程被隐藏，并不约束最终公开统计量泄露多少信息。两类承诺应分别记录，再检查组合后的数据流。

16.2.3 验证结论与适用边界

同一个审计结果只能支持与实验对象相匹配的结论。在已经控制来源差异等混杂因素的条件下，成员推断的有效区分提供参与信息可被利用的证据；内容提取与重构则需要核实恢复内容的来源和特异性；它们不能不经转换就被当成同一强度的泄露证据。

攻击成功可以否定过强的保护主张；攻击失败只说明在所测攻击和资源下没有找到相应泄露。后者不能替代对所有输出事件的隐私定义。反过来，理论参数很大但某个攻击成功率很低，也不应把它解读为参数可以忽略。

经验攻击还可以反过来约束某个隐私主张的可信程度。在固定相邻数

据对和检验事件的实验中，若真实真阳性率与假阳性率为 t, f ，且 $t > \delta$ 、 $f > 0$ ，则差分隐私定义要求 $\epsilon \geq \log((t - \delta)/f)$ 。但实验只能估计 t, f ，应使用真阳性率的置信下界与假阳性率的置信上界，不能把“没有观测到假阳性”直接当成 $f = 0$ 。普通成员与非成员分类实验若没有控制为相邻数据比较，也不能不经论证地套用这个反推。审计证据的含义取决于实验是否真正复现了定义中的比较对象。

评价还需要报告效用和成本。隐私机制输出完全无关噪声可以具有很强保护，却无法完成任务。不同群体的样本量和信号强度不同，噪声造成的效用损失也可能不同，因此应结合第 13 章进行分组检查。

公平审计需要使用敏感属性时，应把“审计所需访问”和“模型日常使用”分开。原始属性可以只在受限审计环境中由指定角色读取，用于计算预先声明的群体指标；训练服务和线上决策不因此自动获得同样权限。对外报告应限制到完成审计所需的统计量，并检查小分组、交叉查询和重复发布是否会暴露成员信息；必要时采用最小组规模、查询预算或与发布目的匹配的隐私机制。验收也要分开进行：公平性证据检查重要群体是否仍有足够样本和有效分母，隐私证据检查谁读取了属性、发布了什么以及多次观察后的泄露边界。简单删除敏感属性会使公平差异无法测量，毫无限制地开放属性又会扩大暴露，两者都没有解决章首提出的取舍。

16.3 隐私保护的实现

保护可以在私人信息进入系统前、转化为模型时，以及交付结果时实施。采集与存储措施决定哪些数据进入系统、谁能够直接读取；训练措施限制数据对参数和中间更新的影响；发布与推理措施约束接收者获得的信息，包括使用过程中新增的私人上下文。这些措施作用于不同位置，可以组合使用，不能用某一个阶段的保护代替全部阶段。下面每种机制都对应前节可以核查的数据流或输出承诺。

16.3.1 数据采集与存储中的保护

不收集无关信息可以减少需要保护的范围。必要信息也应明确使用目的、访问边界和保留时间。但这些措施并不替代输出保护：即使数据库访问受到限制，精确发布一人群体的平均值仍可能直接暴露个人值。

数据最小化需要落实到字段和任务。例如，邮件分类只需要正文的某些特征时，应先检验删除地址、私人编号等无关字段是否仍能完成任务，再决定是否采集或长期保存它们。若目的只需要设备上的预测，可以把处理留在设备上，并检查遥测与日志是否仍上传原文。不采集能够避免这条收集路径产生的风险，但删掉姓名或换成账户代号并不保证匿名：正文、时间和关联记录仍可能帮助识别个人。

对确有必要保存的信息，可以限制可访问角色、隔离用途、设置保留期限，并对传输和存储加密。加密主要限制没有相应密钥者读取内容；能够解密的处理方和最终接收者仍可能看到敏感信息。因此，需要同时控制解密后的使用和对外输出，不能把“数据库已加密”解释为模型不会泄露训练内容。

若确有收集需求，但接收者不应看到准确的个人值，可以在信息离开用户之前实施本地保护。这样改变的是接收者得到的输入；若接收者已经持有明文，之后才随机化发布，就属于不同的信任安排。

二元**随机响应** (randomized response) 通过随机翻转私人位，在发送前限制其可辨识程度，也能说明保护如何影响统计精度。设私人位为 $x \in \{0, 1\}$ ，以概率 $p = e^\epsilon / (1 + e^\epsilon)$ 发送 x ，否则发送 $1 - x$ 。任一消息在两种输入下的概率比至多为 $p / (1 - p) = e^\epsilon$ ，所以满足本地纯差分隐私。若总体中 $x = 1$ 的比例为 μ ，收到的位记为 Y ，则 $\mathbb{E}[Y] = (1 - p) + (2p - 1)\mu$ 。当 $\epsilon > 0$ 时，可用 $(\bar{Y} - (1 - p)) / (2p - 1)$ 估计 μ ；当 ϵ 接近零，分母也接近零，估计误差被放大。强保护并不免费，这个简单例子把隐私与样本量、统计精度的联系直接暴露出来。

16.3.2 训练过程中的保护

模型训练要保留有用规律，又要限制单个对象如何改变发布模型。可以直接限制参数更新，也可以将私人知识限制在受保护的监督接口中。两种方式控制的信息通道不同，但最终都需要分析发布模型对相邻数据变化的可区分性。分析中的敏感度，是相邻数据变化能够造成的最大输出差异；限制这个差异，才能按明确尺度加入噪声。协作训练还需单独处理参与者看到的中间更新。

限制每次更新中的贡献 训练算法通过许多更新累积单个样本的影响。**差分隐私随机梯度下降** (differentially private stochastic gradient descent, DP-SGD) 通过限制样本梯度并对聚合结果加噪，构造可以进行组合分析的更新⁶。

设批次大小为 b ，样本梯度为 $\mathbf{g}_i$ ，裁剪阈值为 $c > 0$ ，则

$$\begin{aligned}\bar{\mathbf{g}}_i &= \mathbf{g}_i \min\{1, c / \|\mathbf{g}_i\|_2\}, \\ \bar{\mathbf{g}} &= \frac{1}{b} \left(\sum_{i=1}^b \bar{\mathbf{g}}_i + \mathbf{Z} \right).\end{aligned}\tag{16.4}$$

零梯度约定仍为零， $\mathbf{Z}$ 为按所用隐私分析校准的高斯噪声。对于固定批次中替换一条记录，裁剪梯度值的敏感度至多为 $2c$ ；增加或删除、抽样和用户级分组采用不同约定时，必须重新匹配敏感度与会计方法。随后用 $\bar{\mathbf{g}}$ 更

⁶ M. Abadi, A. Chu, I. Goodfellow, H. B. McMahan, I. Mironov, K. Talwar, L. Zhang, *Deep Learning with Differential Privacy* In Proceedings of the 2016 ACM SIGSAC Conference on Computer and Communications Security, 2016, pp. 308–318

新参数，并累计所有更新的隐私代价。

因此，一轮 DP-SGD 需要保留“逐样本”这个计算单位：先分别计算梯度，再分别裁剪，随后求和加噪，最后更新参数。若先把整批梯度相加再裁剪，得到的虽然也是有界向量，却不等于式 (16.4)，不能直接沿用其逐样本抽样分析。训练结束只发布最终模型时，还须确认日志或中间检查点没有额外公开未受保护的梯度。

裁剪防止单个样本无限影响更新，却可能引入偏差；噪声进一步降低可辨识程度，也会影响优化。训练轮数、抽样率和噪声强度共同决定预算。用户级保护通常需要限制一个用户的总贡献，不能只逐条裁剪后无条件相加。

更具体地说，可将高斯噪声写为 $\mathbf{Z} \sim \mathcal{N}(\mathbf{0}, \sigma^2 c^2 \mathbf{I})$ ，其中 σ 是相对于裁剪阈值的噪声乘子。若采用独立抽样，每个样本以概率 q 进入本次更新，批次大小是随机的，分母也应按实现和证明采用固定归一化常数或相应处理，不能直接套用固定 b 的公式。Abadi 等人的 DP-SGD 通过裁剪、加噪与矩会计将深度网络训练中的多次访问纳入隐私分析；后续实现也常使用第 16.3.3 节介绍的 Rényi 差分隐私会计，把多次更新的保护强度合并计算。

这里有两种容易混淆的效果。用 T 表示更新次数，固定 q, σ, T 及邻接约定时，按 c 同步缩放噪声，通常不改变由噪声与敏感度之比决定的隐私界，却会改变优化轨迹： c 过小会使许多梯度被压缩，过大又会增加绝对噪声。增大批次也不必然改善隐私；它既改变每次平均更新的信噪比，也改变抽样率和完成既定轮数需要的更新次数，必须在相同训练预算口径下比较。

公开预训练模型上的私有微调提供了另一种效用来源。若预训练不使用本次受保护数据，只对后续私有访问进行会计即可；冻结一部分参数可能降低训练代价，但剩余更新仍需完整裁剪与分析。如果先用私有数据选择预训练模型、构造词表或筛除样本，这些数据依赖步骤不能因为发生在梯度下降之前就忽略。差分隐私承诺覆盖的是发布算法整体。

限制监督标签中的私人知识 若直接对大模型每次更新加噪损失较大，可以让私有模型只提供少量受保护的监督。**教师集成的私有聚合** (Private Aggregation of Teacher Ensembles, PATE) 把敏感数据拆成互不重叠的分区，每个教师只用一个分区训练；学生使用非敏感输入，并从教师的带噪投票中获得标签。私有接口是投票聚合，教师模型本身不发布⁷。

设第 j 类票数为 $v_j(\mathbf{x})$ ，聚合可以发布 $\arg \max_j \{v_j(\mathbf{x}) + Z_j\}$ 。在保持分区规则不变的条件下，更改一条记录最多改变一个教师的投票；一票从一类转到另一类，票数向量的 ℓ_1 变化至多为 2。这个敏感度限制来自教师之间的数据隔离，与每个教师是否采用凸优化无关。若同一用户出现在多个分区中，用户级影响则可能同时改变多个教师，原来的单位又不再适用。

⁷ N. Papernot, M. Abadi, Ú. Erlingsson, I. Goodfellow, K. Talwar, *Semi-supervised Knowledge Transfer for Deep Learning from Private Training Data* In International Conference on Learning Representations, 2017

教师意见一致时，一票改变通常不容易翻转答案；接近平票时，单票影响更值得警惕。可扩展 PATE 进一步采用高斯加噪聚合，并通过带噪的共识检查选择是否回答。它利用投票差距细化隐私分析，但是否通过阈值本身也与私人数据有关，必须计入代价⁸。

拒绝低共识查询还会改变学生收到的训练分布。罕见邮件类型可能恰好更难形成共识，因而更少获得标签；这需要按群体检验获得监督标签的比例及学生模型的效用；标签获得比例并不是预测集合的覆盖率。PATE 的操作顺序是先训练不发布的教师，再为事先说明来源的非敏感输入请求带噪标签，用这些标签训练学生；每次新增教师查询都产生需要计入的隐私访问。与 DP-SGD 相比，PATE 把保护接口放在监督标签上，允许教师内部使用不同训练算法，但需要适合学生学习的非敏感输入，并承受查询数与共识不足的限制。DP-SGD 直接在私有训练更新中限制影响，不依赖教师分片或这类输入。两者都需匹配保护单位，不能只比较最终噪声数值大小来判断谁保护更强。

学生训练只有在不再访问敏感教师或原始数据时才属于后处理。把学生继续放回私人数据上训练，会重新产生需要计入的访问。

协作方可见的中间更新 前面的机制约束发布结果对私人数据的依赖；参与训练的服务器或其他客户端还可能看到发布之前的更新。要保护这些中间观测，需要另行规定参与者的观察权限和串通范围。

安全聚合使服务方只能看到多个参与者的聚合结果，多方计算与同态加密可以在限制中间信息可见性的条件下完成指定计算，可信执行环境则依赖隔离执行和相应硬件假设。这些机制保护计算过程；如果最终模型仍记住私人内容，就还需要控制输出泄露。

Bonawitz 等人的安全聚合协议面向许多客户端向服务器提交向量求和的场景。其基本思路是让客户端发送带掩码的更新，掩码在聚合中抵消，并处理部分客户端退出时的恢复需求。论文分别分析相应对手和串通条件，使服务器在规定条件下获得总和而非单个更新⁹。

隐藏单个更新不意味着总和无害。若一个聚合只剩下一名未知贡献者，其余贡献都为观察者已知，总和就可能确定该贡献；多轮高度重叠的人群统计也可能产生差分信息。因此，安全聚合通常需要与参与人数、串通阈值和发布规则共同解释。它可以承载分布式加噪，但噪声由谁产生、多少诚实参与者留存、退出后总噪声是否仍充足，都属于新的证明条件。

图 3.13 展示了本地记录、客户端更新与中心聚合之间的关系。原始记录留在设备上，上传的更新仍是与私人记录有关的观测，需要按本节的观察权限与串通条件检查。

联邦学习只是把训练计算分散到数据所在位置，并不自动回答这些条

⁸ N. Papernot, S. Song, I. Mironov, A. Raghunathan, K. Talwar, Ú. Erlingsson, *Scalable Private Learning with PATE* In International Conference on Learning Representations, 2018

⁹ K. Bonawitz, V. Ivanov, B. Kreuter, A. Marcedone, H. B. McMahan, S. Patel, D. Ramage, A. Segal, K. Seth, *Practical Secure Aggregation for Privacy-Preserving Machine Learning* In Proceedings of the 2017 ACM SIGSAC Conference on Computer and Communications Security, 2017

件。记录级 DP-SGD 保护本地某条记录，与对每个客户端总更新裁剪后建立用户级保证，也是两种不同方案。若中心服务器被信任，它可以在安全聚合后的总和上加噪；若不信任服务器，客户端需要在协议中共同提供足量噪声或采用其他信任安排。通信加密、聚合保密和统计输出保护应逐层连接，而不是互相替代。

16.3.3 结果发布与推理使用中的保护

发布时需要检查接收者实际拿到什么。开放模型权重、提供受限查询接口和发布一张统计表，对观察者提供的权限不同。减少无关分数、原始记录和调试信息的返回，可以缩小直接暴露范围；限制接口与查询次数，也可以减少特定攻击获得的观察。但若没有相应分析，这些限制不能单独给出差分隐私保证。

发布统计量中的个体影响 当可信管理者已经取得数据时，保护重点转为发布的统计量能透露多少个体信息。精确统计即使没有原文，也可能在小群体或多次差分查询中暴露个人值，因此需要对统计结果本身建立承诺。

设需要发布实值统计量 $F(D)$ ，在既定相邻关系下的敏感度为 $\Delta F = \sup_{D \approx D'} |F(D) - F(D')|$ 。敏感度描述一个受保护对象最多能改变多少输出。为隐藏这种差别，可以发布

$$M(D) = F(D) + Z, \quad Z \sim \text{Laplace}(0, \Delta F / \epsilon), \quad (16.5)$$

其中假设 $\epsilon > 0$ 且 $\Delta F > 0$ 。若敏感度为零，统计量本身不随相邻数据变化，无须为这一目的加噪。

式 (16.5) 满足纯 ϵ 差分隐私。对任意输出位置 u ，两种数据下的密度比为

$$\exp\left(\frac{|u - F(D')| - |u - F(D)|}{\Delta F / \epsilon}\right) \leq e^\epsilon,$$

不等式由三角不等式和敏感度定义得到。对输出事件积分即可得到式 (16.1) 在 $\delta = 0$ 时的结论。这个推导也说明：噪声尺度由数据影响决定，不能任意选择后再解释为隐私参数。

图 16.2 用相差一条记录的计数说明随机化的作用。上部把准确计数与同分布噪声分别送入加法运算，下部显示由随机机制产生的输出分布。观察者拿到的是一次随机输出；保证约束两种可能数据下的全部输出事件，而不是要求这次输出相同。

对前述关键词邮件数，记录级敏感度为 1。若选择 $\epsilon = 0.5$ ，就向准确计数加尺度为 2 的 Laplace 噪声。真实计数相差 1 的两种数据会产生大量重叠输出，查询者不能再仅凭一个精确整数区分目标邮件是否存在。如果保




图 16.2 相邻数据集与随机机制的输出分布。两组记录仅相差新增的一条，计数分别为 3 和 4；每条路径各加一个独立的尺度 1 拉普拉斯噪声，对应 $\Delta F = 1$ 、 $\epsilon = 1$ 、 $\delta = 0$ 。加法节点显示噪声如何进入发布值；两侧是相邻数据的替代发布情形，不表示同时公开两次结果。下部实线与虚线是解析密度，阴影比较同一事件 $E = [5, 6]$ 的概率，横轴仅展示部分范围。观察者得到一次输出；隐私保证要求对所有相邻数据和所有输出事件成立，不能只看曲线重叠。

护单位改为一个用户，而每人最多贡献 10 封相关邮件，计数敏感度变为 10；保持相同 ϵ 需要尺度为 20 的噪声，除非重新设计贡献限制。这些数值只是定义和机制的代入，显示保护单位、效用损失与实际实现如何相连。

示例 16.3 计数与平均值的不同要求 按增加或删除一条记录定义相邻时，人数计数的敏感度为 1。若发布固定 n 条记录中数值的平均值，按替换一条记录定义相邻，且每条数值预先限制在 $[0, 1]$ ，敏感度为 $1/n$ 。去掉取值界后，均值敏感度可能无界。两种例子使用不同相邻约定，必须分别写清。

推理上下文与结果接收者 推理阶段也有独立的信息流。检索私人文档、调用工具和记录对话日志，可能将敏感内容带到新的边界。应只提供完成任务必要的上下文，限制工具返回字段，并对输出对象和接收者进行检查。对私人上下文提供形式化保护时，每次新访问都应纳入相应机制的分析。

这里的保护对象是当前请求中的私人信息，而非仅限于训练记录。一个

已经具备训练数据差分隐私保证的模型，如果收到私人邮件后原样转交外部工具，仍然可能泄露该请求。应在上下文进入模型、工具接收字段和结果交付接收者这几处分别明确边界；训练阶段的保证不会自动覆盖新增输入。

实际控制可以从检索前的权限检查开始：仅让当前用户有权访问的文档进入上下文，按工具任务裁减字段，对回复和工具请求检查接收范围，并限制日志保存内容。输出过滤能够拦截已知标识或特定模式，但可能遗漏改写和间接推断，也可能误删合法内容，应该通过前节的结果检验与过程核查分别验证。过滤有效不等于私人上下文已经获得形式化保护。

多次发布的累计保护强度 若已经发布 $M(D)$ ，再用不访问原始数据的随机过程处理它，不会增加差分隐私参数。这称为后处理性质：对处理后任一输出事件，可以把它追溯为原机制输出上的一个随机检验，并继续应用式 (16.1)。

如果重新访问数据运行多个机制，情况不同。基本组合界将每一步的 ϵ 与 δ 分别相加；更精细的会计可以利用机制结构获得更紧的界，但不能忽略重复试验和模型选择。对已发布私有模型作纯后处理查询，与每次查询都重新读取私人上下文，是两种不同的信息使用过程。

只要多次发布都依赖同一个受保护对象，就需要计算联合观察下的保护强度。下面给出训练和持续服务中可用的组合分析。它适用于前述各阶段，不是一个额外的数据处理阶段。

以 $\epsilon = 0.5$ 的关键词计数服务为例，对同一批邮件重新抽取噪声并发布三次，基本组合给出 1.5 的纯差分隐私上界；若只是把已经发布的一次带噪计数画成图、转换单位或重复显示，则属于后处理，不增加这项预算。若三次调用来自不同网页或不同功能，只要它们读取的是同一个受保护对象，也不能因此分开忽略。累计分析针对观察者能够联合看到的结果。

训练往往包含成千上万次更新，逐步转换为 (ϵ, δ) 再相加可能过于保守。**Rényi 差分隐私** (Rényi differential privacy, RDP) 保留输出分布差异在不同阶数下的信息，便于先组合、后转换。对概率分布 P, Q 和 $\alpha > 1$ ，定义

$$D_\alpha(P||Q) = \frac{1}{\alpha - 1} \log \mathbb{E}_{o \sim Q} \left[\left(\frac{dP}{dQ}(o) \right)^\alpha \right]. \quad (16.6)$$

若对所有相邻数据集，该量均不超过 $\rho(\alpha)$ ，就得到相应阶数的 RDP 保证。这里假设所需绝对连续性成立；不满足时散度可以为无穷大。Mironov 建立了这种定义及其组合、后处理和转换性质¹⁰。

若第 t 次机制在给定此前输出后仍满足统一的 RDP 界 $\rho_t(\alpha)$ ，则组合界

¹⁰ I. Mironov, *Rényi Differential Privacy* In 2017 IEEE 30th Computer Security Foundations Symposium, 2017

为 $\sum_t \rho_t(\alpha)$ 。对事先指定的 $\delta \in (0, 1)$ ，一个有效的转换结果是

$$\epsilon(\delta) = \inf_{\alpha > 1} \left\{ \sum_{t=1}^T \rho_t(\alpha) + \frac{\log(1/\delta)}{\alpha - 1} \right\}. \quad (16.7)$$

上式中的最小化是在已经证明有效的阶数界之间选择，不需要再访问私人数据。例如，不含抽样的高斯发布机制具有 $\rho(\alpha) = \alpha \Delta_2^2 / (2s^2)$ ，其中 Δ_2 为向量统计量的二范数敏感度， s 为各坐标噪声标准差。训练中的抽样会改变这条曲线，必须使用相应抽样机制的分析，不能把抽样率随意乘到最终 ϵ 上。

16.4 数据撤回与模型消除

本节的模型消除主要指消除指定数据在模型中的训练影响，即**机器遗忘** (machine unlearning)；删除或停用整个模型是另一种操作。删除数据库中的记录、阻止某段文本出现和消除训练影响，具有不同的验收对象。

记训练算法为 A ，原数据为 D ，待撤回记录集合为 F ，模型更新程序为 U 。图 16.3 把删除后的数据与模型更新分开。清理数据不会自动改变先前训练的模型；消除训练影响需要将更新结果与从未使用撤回记录的重训练结果比较。未能提取私人片段，也不能仅据此认定训练影响已经消除。




图 16.3 撤回记录与消除训练影响的两条路径。下方清理数据 $D \setminus F$ 留下撤回位置，上方旧模型 $A(D)$ 不会因此自动改变；更新程序 U 另行读取旧模型、原数据和撤回集合。更新结果与从未使用 F 的重训练参照比较输出分布；精确遗忘要求同分布，近似遗忘须声明距离或可区分性标准。

在集合差按记录身份处理的约定下，精确遗忘要求更新程序 U 满足

$$U(A(D), D, F) \stackrel{d}{=} A(D \setminus F). \quad (16.8)$$

这里 $\stackrel{d}{=}$ 表示输出分布相同，概率包含训练与遗忘算法的随机性。右侧是从未使用撤回记录的重训练参照。实际程序可以使用额外保存状态，但若这些状态会发布，也应纳入比较。

近似遗忘允许两种分布在指定距离或可区分性标准下接近。必须说明比较对象是参数、预测行为还是某类攻击结果；只在少量问题上不再输出原文，不能推出参数分布已经接近重训练。

差分隐私与遗忘也不等价。前者在训练时限制一个对象对输出的影响，后者在撤回后与特定重训练结果比较；二者可以配合，但不能仅凭训练使用了差分隐私便宣称完成了任意撤回要求。

一次撤回不等于任选一种操作。每项请求都要先确定撤回范围，停止相关数据继续被正常使用，清理可控制的数据副本与衍生状态，并隔离暂时无法清除的部分。若撤回数据已经影响训练结果，还需从完整重训练、局部重算和参数修正中选择满足既定遗忘标准的路线；三者是备选方案，不是需要依次执行的步骤。撤回的正式处置完成前，输出限制只能作为过渡保护。最后还要统一验收数据资产、服务接口和模型影响，并报告完整流程的时间与资源代价。

16.4.1 撤回范围与数据资产清理

撤回从定位范围开始。应根据稳定的记录标识、用户与记录的关联，以及处理过程留下的依赖关系，找出原始文件、清洗副本、特征缓存、检索索引、向量记录、训练快照和相关日志。对用户级撤回，不能只删除账户表中的一行；对包含多个人信息的共同记录，还要说明本次实际删除的是整条记录还是其中的字段。

减少响应时间的关键是事先能够查出数据去向。可以维护记录到数据版本、索引条目、训练任务和模型版本的映射，按这份映射生成撤回任务。请求确认后，先阻止相关数据继续进入训练队列、检索结果和新的副本，再按存储与依赖清单安排各位置的清除或重建，并检查正在运行的任务是否仍持有旧快照。删除标记只表示数据不可再被正常使用，与物理副本已经清除是两种完成状态。

清除顺序还要与模型更新协调。后文的贡献扣除需要计算撤回记录的统计量，部分参数更新也需要在撤回样本上计算损失；这些计算若依赖原始内容，就应在受限的撤回处理环境中完成，再清除相应工作副本。也可以在已有状态足够时直接使用必要统计量，但这些状态本身仍须检查是否含有私人信息。先停止正常训练与检索中的使用，不等于必须先销毁遗忘算法尚需读取的全部输入；临时副本的访问范围、存续时间和最终删除，都属于同一次撤回的验收范围。

索引删除尤其需要检查派生缓存。例如，移除文档后，其向量、缓存

片段和已生成的摘要仍可能被检索或复用。备份恢复也应重新应用撤回记录，避免已经删除的数据在恢复后重新进入服务。若某些归档不能立即逐条清除，应明确其隔离措施、清除安排和恢复限制，不能把在线不可见写成所有副本已经消失。

验收时应按存储和依赖清单核对已完成、待完成与无法控制的副本，测试撤回记录是否仍能被检索、导出或再次进入训练，并记录涉及的模型版本。日志应能证明处置过程，同时避免为了审计重新保存完整私人内容。数据资产清理完成，只解决系统仍保存或重新使用什么；已经写入参数的训练影响还需选择下面的消除方案。

16.4.2 训练影响的消除方案

数据进入训练结果后，需要选择与遗忘标准、算法结构和可用状态相匹配的消除方案。完整重训练直接构造参照；局部重算利用可追踪的计算依赖减少工作量；参数修正则从现有模型出发逼近删除后的结果。三条路线的适用条件和证据强度不同，不能把计算量较小直接解释为遗忘更充分。

完整重训练 最直接的方法是排除撤回集合 F ，在 $D \setminus F$ 上重新执行训练算法 A 。这条路线直接构造式 (16.8) 右侧的参照，代价是重新处理保留数据与训练模型。这里的参照是同一训练流程在保留数据上产生的模型分布，不要求恰好复现某一组随机参数。

完整重训练还包括受撤回数据影响的前置步骤。若词表、特征标准化、样本筛选或模型选择曾使用 F ，就应重新计算这些依赖；若优化器状态或初始化检查点已经受 F 影响，直接从该状态继续训练也不等于从未使用 F 。只有确认独立于撤回数据的公开预训练模型或中间结果，才可以作为可复用起点。提前停止的轮数、随机抽样规则与其他训练约定也属于 A 的一部分。

重训练后需要切换服务版本、失效旧缓存，并清楚标识新模型覆盖了哪些撤回请求。多项请求可以合并重训以减少重复计算，但等待期间仍需要限制旧数据与旧服务的暴露，且必须报告实际等待时间。批量处理改变的是效率，不能把“已经进入下一批任务”写成模型影响已经消除。

局部重算 要比完整重训更快，需要知道撤回数据影响了哪些计算。若模型只依赖可更新的统计量，可以扣除被撤回记录的贡献；若训练事先被隔离为若干部分，可以仅重算受影响的部分。节省来自明确的计算依赖，而不是从任意神经网络参数中直接找到一条数据对应的位置。

当训练结果由可更新统计量决定时，可以直接扣除撤回记录的贡献。Cao 和 Yang 研究把学习过程组织为可更新的求和形式，在撤回时修改相关统

计量,以减少重新处理全部数据的代价。这种思路要求算法与数据处理确实具有相应结构,并需要追踪衍生数据的依赖¹¹。

设一个教学估计器只通过记录数 n 与数值和 S 得到均值 $\hat{\mu} = S/n$ 。若撤回 $m < n$ 条记录,其数值和为 S_F ,则更新为

$$\hat{\mu}_- = \frac{S - S_F}{n - m}.$$

这与对保留记录重新计算均值在数学上相同,只需取得撤回集合的贡献;数值实现仍需考虑浮点误差。例如原数据为 1,2,3,撤回 3 后,直接更新得到 $(6 - 3)/(3 - 1) = 1.5$ 。这说明在特定模型中可以通过更新状态精确移除贡献,但不意味着深度网络也能把某个样本的训练梯度简单减回去:后续更新依赖先前参数,通常会受到连带影响。

若计算依赖在训练前已经隔离,局部重算还可以只触及受撤回记录影响的部分。SISA 训练把计算依赖组织为分片、隔离、切片与聚合 (Sharded, Isolated, Sliced, and Aggregated): 各分片独立训练子模型,分片内部按切片逐步训练并保留检查点,最终聚合子模型预测。撤回一条记录时,从该记录首次进入训练之前的检查点恢复,只重新训练受影响的后续部分。它用事前隔离换取撤回时的局部重算¹²。

例如,把邮件按预先固定的规则分到四个分片,每片分成三个顺序切片。某条待删除邮件只位于第二分片的第二切片,则其他三个子模型无需变化,第二分片第一切片结束的状态可以保留,后两片在排除该邮件后重算。这一教学例子中的节省来自依赖关系,而不是算法能够从任意最终参数中抽出一条记录的影响。如果特征标准化、词表或模型选择在全部数据上共同完成,仍可能留下跨分片依赖,必须纳入撤回流程。

分片越多,每个子模型可用的数据越少,集成预测与整批训练也可能具有不同效用;检查点越密,存储和敏感状态管理代价越高。因而不能只比较一次删除的耗时。应同时比较初始训练、状态保存、常见删除批量、最坏删除分布和保留任务的效果,并固定重训练基线的算法。

这里的局部重算应与同一分片、切片和聚合规则下的重训练比较,并核对数据移除后抽样与随机状态的处理是否一致。与一个从头训练的整批单模型相比,SISA 本来就是另一种训练算法,不能据此宣称二者输出分布相同。

参数修正与近似遗忘 如果没有预先隔离所有依赖,可以尝试从已有参数出发逼近删除后的模型,但“修正得很小”与“删除得充分”没有必然关系。

一种参数修正路线为近似误差给出理论控制。Guo 等人的认证数据删除针对有正则化的线性模型,利用牛顿更新近似删除后的解,再用训练时

¹¹ Y. Cao, J. Yang, *Towards Making Systems Forget with Machine Unlearning* In 2015 IEEE Symposium on Security and Privacy, 2015

¹² L. Bourtole, V. Chandrasekaran, C. A. Choquette-Choo, H. Jia, A. Travers, B. Zhang, D. Lie, N. Papernot, *Machine Unlearning* In 2021 IEEE Symposium on Security and Privacy, 2021

的目标扰动隐藏剩余误差。其保证依赖强凸性、平滑性等条件；仅有很小的梯度残差并不能独立证明删除成功¹³。

这个机制可以用优化残差理解。设原参数为 $\hat{\theta}$ ，删除后的光滑强凸目标为 $L_-(\theta)$ ，在原参数处的梯度和海森矩阵分别为 $\mathbf{g}_-$ 和 $\mathbf{H}_-$ 。一步牛顿近似为

$$\tilde{\theta} = \hat{\theta} - \mathbf{H}_-^{-1} \mathbf{g}_-. \quad (16.9)$$

若删除后目标在局部接近二次函数，这一步能消除主要的一阶偏差；剩余误差可用 $\|\nabla L_-(\tilde{\theta})\|_2$ 描述。但确定性的微小误差仍可能携带记录信息，因为观察者可以检查非常精细的参数差别。认证方法还需要把残差界与随机扰动分布连接，证明删除输出与重新训练输出在指定可区分性标准下接近。

强凸性给出的是一个相关但较弱的结论：对无约束可微目标，若强凸参数为 $\lambda > 0$ 、真正最优解为 θ^* ，则 $\|\tilde{\theta} - \theta^*\|_2 \leq \|\nabla L_-(\tilde{\theta})\|_2 / \lambda$ 。它说明优化误差可以由残差控制，却还不是输出分布的隐私界。连续撤回时，残差和认证预算需要累积；当条件超出允许范围，重新训练是恢复承诺的一种方式。把针对强凸线性模型的推导直接套到大规模非凸语言模型，会丢失决定认证是否成立的关键前提。

对不满足上述认证条件的深度模型，也可以采用经验更新：在撤回数据上提高预测损失，使模型降低对相应答案的概率；同时在保留数据上继续降低任务损失，或约束模型在这些数据上的预测变化。前一项促使模型遗忘，后一项限制附带损伤。若不使用保留约束，只反复提高撤回损失，模型可能通过破坏大量能力达到这一目标，因而不能把撤回集准确率越低理解为遗忘越充分。

负偏好优化（Negative Preference Optimization, NPO）研究了语言模型遗忘中的这一不稳定性。它以原模型作为参考，用目标序列在当前模型与参考模型下的相对概率调节遗忘更新；当某个目标已经被明显压低后，其更新权重随之减小。该目标可以与保留数据的训练损失结合，以限制效用损失。它提供了一种调整参数的经验路线，并不自动证明任意语言模型已接近完整重训练的参数分布¹⁴。

第 15.3.3 节中的局部影响近似也可以帮助估计参数修正方向，但大范围删除通常超出线性近似条件。解释中的数据归因询问样本如何影响行为，遗忘则要求修改后的输出满足与重训练有关的标准；即便影响方向估计准确，也还缺少后者所需的误差与分布比较。连续删除还需要检查近似误差是否累积。

选择方案时，应先固定遗忘标准，再寻找满足标准且响应代价可接受的方法。完整重训练适用范围较广，但代价可能高；可更新统计量与隔离训练能够利用既有结构减少重算；参数修正需要分别给出认证条件或经验边

¹³ C. Guo, T. Goldstein, A. Hannun, L. van der Maaten, *Certified Data Removal from Machine Learning Models* In Proceedings of the 37th International Conference on Machine Learning, 2020, pp. 3832–3842

¹⁴ R. Zhang, L. Lin, Y. Bai, S. Mei, *Negative Preference Optimization: From Catastrophic Collapse to Effective Unlearning* In arXiv preprint arXiv:2404.05868, 2024

界。若近似方法达不到所需标准，应回到重训练或收紧服务范围，不能仅因它最快便称为最优。

16.4.3 撤回完成前的过渡保护

撤回所需的数据清理或模型更新尚未完成时，可以先在可控制的接口上限制暴露：撤下相关检索文档、使缓存失效、限制敏感请求的可见字段、拒绝向无权接收者交付内容，或在回复中屏蔽已知私人标识。这些措施直接改变服务能够返回什么，可以作为撤回响应的一部分。

但只在最终文本中过滤项目编号，并没有改变模型参数。改写编号、询问关联事实、换用接口或直接读取旧权重，都可能超出过滤规则的覆盖范围。拒答微调虽然会更新参数，也可能只是让模型学会避开一类问题，不能仅据拒答增加推断训练影响已经消失。知识编辑同样需要额外证明，才能从“某个答案改变了”上升为“指定数据的影响接近重训练参照”。

移除检索源与过滤输出还应分开验收。若信息只保存在外部检索库中，删除记录、索引和缓存可以切断这条信息来源；若基础模型也曾用相同内容训练，切断检索并不处理参数中的记忆。应根据数据去向决定是否还需要选择训练影响消除方案，而不是对所有撤回请求都采用同一种操作。

输出限制可以先行实施，影响消除随后完成，但两者应分别报告状态、接口范围和验收结果。已经交付给外部接收者的内容或模型副本，不会因本地更新自动消失；本节讨论的处置只能覆盖明确可控制的状态与服务。

16.4.4 撤回结果与效率的验收

撤回验收应分别核对三种结果：数据副本是否按清单删除或隔离，临时输出限制是否在声明的接口生效，以及模型影响是否满足选定的遗忘标准。若撤回记录没有进入任何训练结果，模型影响项可以记为不适用，但应保留支持这一判断的数据流与版本证据。三种结果不能互相代替。若撤回数据已经影响旧模型，完成记录删除却继续使用该模型；或者虽然更新模型，却仍让旧样本进入下一轮训练，这两种情形都表示整个撤回流程尚未完成。

训练影响是否消除，要回到式(16.8)规定的参照，而不能只看重算量或参数变化幅度。验证应同时检查待消除信息、保留任务和重新训练参照。在受控比较中，应冻结删除集合 F 、剩余数据及训练规则，分别保留原模型、遗忘后的模型和用 $D \setminus F$ 重训练的模型；三者使用相同测试请求和攻击预算。对含项目编号的邮件，比较编号提取情况与对应记录的成员分数，同时在保留邮件上测量分类风险、概率校准及受影响群体的表现。由于训练和生成可能随机，单个模型的一次输出不足以比较输出分布；需要重复训练或采样，并说明可重复次数和估计误差。需要使用不同提示、采样方

式和攻击预算，检查结果是否只是表层拒答。

以邮件中的私人项目名为例，删除后模型不再复现原句，只检验了精确匹配；改写提示、相关事实和多轮问答可能仍暴露同一信息。反过来，一个从未使用该邮件重新训练的模型，也可能从保留邮件中学到项目名。此时要求项目名完全不可回答，是比“消除指定记录影响”更强的知识删除目标，应重新规定参照数据与知识范围。否则，评价会把重新训练本来也会知道的事实误判为删除失败。

成员推断在遗忘评价中也需要重新设定攻击参照。原始模型上的成员、普通非成员和撤回记录不再是同一种比较；遗忘后的样本若被过度排斥，异常高的损失反而可能暴露“它曾经被撤回”。审计应比较遗忘模型与重训练模型上对应记录的分数的分布，同时观察相似保留样本。只让撤回样本变得比所有其他样本都难预测，并不意味着接近重训练。

保留效用既包括整体性能，也包括与撤回对象相邻的能力。删除一个人的私人经历，不应在没有目标依据的情况下让整个职业类别都无法回答；为了删除某个样本而破坏预测校准，也会把代价转移到第 11 章关注的决策环节。因而遗忘评价应报告同一删除范围下的残留信息、保留风险、更新时间与状态存储，并说明哪些量有理论保证，哪些只有经验结果。

效率也应按完整流程测量。从请求被接受到停止继续使用数据、从停止使用到可控副本清除、从请求到新模型上线，是不同的时延；仅报告参数更新的几秒钟，会漏掉定位、排队、索引重建、检查与版本切换。比较方法时还应计入初始训练和额外状态存储，并在相同删除规模、硬件与效用要求下报告结果。

连续撤回与旧、新版本同时可见时，还需检查累计误差和联合观察；更新后的单模型结论不能撤销外部观察者已取得的信息。验收记录应据此区分数据资产、过渡保护和模型影响的完成状态，不能用其中一项通过替代整个撤回流程完成。

16.5 前沿研究

基础模型把前述问题扩展到两类新边界：推理时临时提供的信息怎样获得明确保护，以及遗忘后的模型在多次生成中是否仍暴露目标信息。前者延伸数据使用机制，后者加严撤回效果的验证；二者需要分别规定保护对象与观察预算。

16.5.1 推理上下文的细粒度保护

推理时新增的私人上下文不属于训练数据保护的覆盖范围，需要单独规定保护对象与接收者，基本边界见第 16.3.3 节。DP-Fusion 研究词元级私有推理，通过比较包含与不包含指定敏感词元的输出分布来限制影响。其保

护单位是规定的敏感词元和相应机制，不能直接解释为整个用户或全部关联事实的同强度保护¹⁵。

DP-Fusion 把移除敏感词元时的推理分布作为基准，再将使用完整上下文所得的分布与基准融合，限制发布分布相对于基准的偏离。这样可以继续利用敏感上下文中的一部分信息，同时控制其对输出的影响。该机制把过去常在训练阶段提出的“单个对象改变多少输出”问题，延伸到文档改写等推理任务。

从这一思路还可以看出保护边界的重要性。若私人项目名被标为敏感词元，但地址、时间和职责组合仍足以识别该项目，仅保护项目名字面变化并没有覆盖全部关联信息。敏感范围的标注、邻接定义与多次生成的组合应一起检查；一次文档发布的参数不能不经分析就用于任意长度的持续对话。

16.5.2 多次生成下的遗忘检验

遗忘研究中的另一个问题是评价是否充分。Leak@k 检查被遗忘信息在多次随机生成中重新出现的情况，表明在论文所测方法和任务中，贪心解码下看似成功的遗忘可能掩盖其他生成路径的泄露。这将验证对象从一次输出扩展为查询策略和预算下的可提取信息¹⁶。

可以用一个独立采样的教学模型理解查询预算。固定模型、问题和采样分布，设一次生成泄露目标信息的概率为 p ，则 k 次独立生成中至少泄露一次的概率为 $1 - (1 - p)^k$ 。若 $p = 0.01$ ，一百次生成的累计概率已经约为 0.634。真实评估还可能使用连续泄露分数或自适应提示，不能直接用这个简化公式替代论文指标；它说明一次未出现并不代表其他生成路径已消失。

这种压力测试仍需与重训练参照结合。若某个指标把保留数据中也能推出的事实计为泄露，增加采样次数也会提高重训练模型的分值。只有明确目标知识、比较模型和评分规则，才能区分未消除的训练影响与本来允许保留的知识。这也呼应第 16.2 节的原则：强攻击扩大了可见证据，不能替代保护对象的定义。

更长的数据处理链还涉及衍生模型、外部索引与多次更新。未来保护需要把影响的定义、保存状态和可验证删除连接起来。单个机制参数再明确，也不能自动覆盖链条中未纳入分析的发布渠道。

16.6 本章小结

私人邮件的保护始于明确人、信息和接收范围。训练成员身份、邮件内容与推理时新提供的上下文是不同秘密，可能通过原文、中间更新、参数和

¹⁵ R. Thareja, P. Nakov, P. Vepakomma, N. Lukas, *DP-Fusion: Token-Level Differentially Private Inference for Large Language Models* In International Conference on Learning Representations, 2026

¹⁶ H. Reisizadeh, J. Ruan, Y. Chen, S. Pal, S. Liu, M. Hong, *Leak@k: Unlearning Does Not Make LLMs Forget Under Probabilistic Decoding* In Proceedings of the 43rd International Conference on Machine Learning, 2026, pp. 104291–104315

服务输出泄露。保护单位与观察权限决定承诺覆盖什么，差分隐私进一步约束指定对象对发布分布的影响，但不能替代访问和用途边界。

结果检验寻找实际可以获得的私人信息，成员身份、未公开属性、原文提取和输入重构需要各自匹配攻击者知识与判据；过程核查则检查数据流和机制条件。攻击成功能够揭示对应渠道的泄露，攻击失败只能说明在既定权限与预算下尚未发现；形式化保证还需要有效定义、数学分析与正确实现共同支持。采集时减少不必要信息、训练时约束贡献和中间观测、发布时限制结果与接收者，分别控制不同阶段的风险，多次使用还需要合并计算保护强度。

公平审计所需的敏感属性可以在职责隔离、最小访问和受控发布条件下使用。公平性验收关注分组证据是否充分，隐私验收关注属性流向与统计发布是否越界；减少一方所需信息会改变另一方的证据能力，因此两类结果必须并列报告。

撤回一封邮件时，定位范围并清理数据资产是必做任务；数据已经进入训练结果时，还要从完整重训练、局部重算和参数修正中选择符合遗忘标准的消除方案。输出限制可以在撤回完成前降低暴露，却不能据此宣布训练影响已经消除。最终验收需要分别核对数据资产、接口限制和模型影响，并同时报告删除目标、保留效用和完整响应时间。

下一章进一步考察主动攻击者如何利用系统中的薄弱环节。本章的信息流边界、泄露审计和撤回验证，为分析其中的私人信息损害与恢复措施提供了基础。

延伸阅读 Dwork 与 Roth 的专著适合系统补充差分隐私的机制、组合和统计代价；Abadi 等人的 DP-SGD 则展示了裁剪、噪声与多次更新会计怎样进入深度模型训练。阅读时应始终核对相邻关系和保护单位，不能把记录级参数直接解释为用户级保证¹⁷。。

若关注模型发布后的泄露与撤回，可结合 Carlini 等人的训练数据提取研究和 Bourtole 等人的 SISA 遗忘方案。前者说明查询接口怎样暴露训练片段，后者说明预先隔离计算依赖怎样降低删除重算代价；经验攻击失败与接近重训练仍是两种不同证据¹⁸。。

¹⁷ C. Dwork, A. Roth, *The Algorithmic Foundations of Differential Privacy* In *Foundations and Trends in Theoretical Computer Science*, 2014, vol. 9, no. 3–4, pp. 211–407; M. Abadi, A. Chu, I. Goodfellow, H. B. McMahan, I. Mironov, K. Talwar, L. Zhang, *Deep Learning with Differential Privacy* In *Proceedings of the 2016 ACM SIGSAC Conference on Computer and Communications Security*, 2016, pp. 308–318

¹⁸ N. Carlini, F. Tramer, E. Wallace, M. Jagielski, A. Herbert-Voss, K. Lee, A. Roberts, T. Brown, D. Song, U. Erlingsson, A. Oprea, C. Raffel, *Extracting Training Data from Large Language Models* In *30th USENIX Security Symposium*, 2021; L. Bourtole, V. Chandrasekaran, C. A. Choquette-Choo, H. Jia, A. Travers, B. Zhang, D. Lie, N. Papernot, *Machine Unlearn-*

对抗安全

邮件分类器可能因新月份的语言变化而误判，也可能因为有人专门改写邮件来逃避检测而失效。后者需要主动寻找薄弱点，并选择有利于攻击目标的输入或操作。若分类器进一步接入自动归档、检索和发送工具，攻击造成的后果就可能从判断错误扩大到信息泄露或越权执行。

在第 10 章的三层架构中，对抗安全主要位于威胁与生命周期治理层。系统属性或规范要求层先给出攻击不得破坏的任务目标、隐私要求和行为边界，证据能力层提供脆弱性测试、机制分析与审计；本章再把攻击者的知识、权限、资源与目标纳入条件，并据此安排防御、监测和恢复。

对抗安全（adversarial security）讨论机器学习系统怎样抵御这种有目的的操纵。攻击的定义、例子与损害用于确定保护目标。脆弱性评估检查输入、训练过程、模型内部、查询接口和执行链中的薄弱环节；防御则在相应位置减少攻击机会、限制模型受影响的程度，并控制已经发生的损害。分布偏移（第 9.1.2 节）描述训练分布与评价分布的差异，算法稳定性（第 7.3 节）考察训练样本变化对输出或损失的影响，隐私泄露（第 16.1.2 节）关注系统暴露了什么信息；这些现象即使没有攻击者也可能发生。对抗安全进一步要求有人在其知识、权限和资源范围内有目的地选择变化，并追踪这种操纵怎样经过系统响应和下游动作形成损害。本章据此检验整个系统能否守住规定的安全边界。

17.1 对抗安全的基本概念

17.1.1 对抗攻击及其典型表现

对抗攻击（adversarial attack）是攻击者有目的地选择或操纵机器学习系统能够接触的输入、训练材料、模型组件或交互过程，使系统违背预期任务或安全要求的行为。它既包括让分类器作出错误判断，也包括获取不应公开的信息、不当占用服务资源或诱导越权操作。本章采用这一较宽的含义；狭义的输入扰动攻击只是其中一种。

攻击与普通错误的区别在于有目的的选择和利用。系统偶然误判一封

邮件，只能说明存在错误；有人反复试探并选择能够逃过过滤的写法，才构成这里讨论的攻击过程。反过来，攻击已经发生也不意味着攻击已经成功：输入可以被拒绝，错误建议可以被执行器拦下，实际损害还要另行判定。

攻击入口是攻击者可以施加影响的位置。下面沿同一个邮件系统说明几类典型表现；这些是帮助区分机制的教学情境，不是已发生事件的记录。

输入攻击改变模型看到的内容。**对抗样本**（adversarial example）在规定的修改范围内诱导不期望的预测，范围可以是数值扰动，也可以是任务允许的文本或物理变化。修改是否保留原任务标签需要核验，否则测试可能混入任务本身已经改变的输入。例如，攻击者改写钓鱼邮件的措辞，使分类器将其判为正常邮件，而邮件的欺骗目的仍未改变。

训练阶段的**数据投毒**（data poisoning）通过修改训练数据改变学到的模型；**后门**（backdoor）使模型在特定触发条件下表现异常，同时可能保留正常输入上的性能。干净测试集准确率因而不足以排除后门。联邦或协作训练中，恶意参与者提交的更新也属于训练入口，需要明确其比例和可控内容。例如，污染反馈数据使某类钓鱼邮件被当作正常样本学习，或让带特定标记的邮件在部署后被放行。后门既可以通过数据投毒植入，也可以通过受污染的模型参数进入系统，因此投毒描述操作过程，后门描述被植入的异常行为。

模型服务还暴露查询与输出。模型窃取关注攻击者能否复制有价值的功能或信息，其目标不同于第 16.1 节的个人数据泄露。两者可能使用相似查询接口，却需要不同的成功定义和防御代价评价。例如，攻击者在预算内反复查询分类器，再训练一个具有近似判断能力的替代模型；私人邮件内容被恢复则属于另一种信息损害。

对于具有工具和检索能力的生成系统，**提示注入**（prompt injection）把攻击指令放进模型要读取的内容中，试图改变原任务；间接注入将这些内容置于第三方文档、网页或工具返回值。**越狱**（jailbreak）则试图使模型突破既定行为限制。二者可能结合，但来源、目标和系统权限仍需分别说明。例如，助手读取一封邮件以生成摘要，正文却夹带要求归档其他邮件的指令。它利用的是系统对内容角色和操作权限的处理，而不要求对输入施加肉眼不可见的扰动。

17.1.2 攻击影响与损害路径

损害目标需要与正常任务区分。逃过分类、诱导指定错误、提取训练信息、复制模型功能和执行未经允许的工具动作，是不同目标。若只把所有失败合成一个“攻击成功率”，就无法知道主要损害来自哪里，也难以选择防御位置。

损害分析还要区分单个样本与整个服务。攻击者可能希望让某封钓鱼邮件通过，也可能希望大量正常邮件被隔离，从而使用户关闭过滤功能。前者破坏决策的完整性，后者损害服务的可用性；若攻击使助手泄露其他邮件，则涉及机密性。把三种损害分开，才能解释为什么提高邮件获得放行所需的可信分数阈值，可能抑制第一种攻击，却加剧第二种损失。

例如，用户授权助手归档指定类别的邮件，某封邮件正文却声称“应立即归档全部邮件”。这段文字可以是待分析数据，却没有因此获得操作其他邮件的权限。攻击成功依赖系统把内容提升为行动依据，而不只依赖模型生成了某句话。

一次攻击通常沿“可控入口—系统响应—下游动作—损害”传播。输入修改是否令分类器翻转、训练污染是否改变后来学到的规则、工具返回值是否诱导越权动作，是不同的中间事件。评估应沿实际路径观察，不能仅凭中间事件替代损害结果。例如，模型提出越权操作说明行为受到操纵，但只有执行端实际允许该操作，才产生相应行动损害。

同一目标也可能有多条路径。让一封钓鱼邮件通过，既可以改写这封邮件，也可以提前污染训练数据；两者都损害决策完整性，却需要不同权限、预算和测试过程。这说明攻击入口与损害目标是交叉关系，评估既要覆盖不同入口，也要使用与各自损害对应的判据。

可用性攻击还可能主要消耗资源，而不改变答案。例如，在受控测试中让请求持续占用计算、使任务陷入重复调用，可以观察队列等待、正常请求完成率和资源开销是否恶化。这类试验应报告单位请求及整个攻击过程的成本，并与同负载的正常使用比较，避免把普通容量不足误认成特定攻击机制。

17.1.3 攻击能力与威胁模型

威胁模型（threat model）规定攻击者想达到什么结果、能观察和改变什么，以及受到什么资源限制。这些条件共同限定安全结论：攻击入口说明通过哪里施加影响，知识与权限说明可以如何操作，损害目标说明什么结果才算成功。同一次攻击可以同时具有特定入口、知识条件和损害目标，因此不能把三个维度的取值列成互斥类别。

在给定威胁模型下，安全要求可以表述为：允许的攻击过程不应使系统产生规定的损害，或者其损害风险应低于容许水平。“允许”指测试给予攻击者的能力范围，并非给予其现实行动许可。例如，测试可以允许攻击者改写邮件内容，却不允许直接修改收件箱数据库。前者需要检查模型与执行机制如何响应，后者若被错误地纳入测试，便绕过了原本希望评价的防护环节。

白盒攻击可以访问模型参数或梯度，黑盒攻击可能只得到查询结果；实

际系统还可能向攻击者暴露部分结构、版本和错误信息。知道参数与能够修改参数也应区分，前者可以帮助寻找输入，后者则可能直接改变模型。

资源限制包括查询次数、修改幅度、能够污染的数据量和可控制的参与者数量。较强权限下找到的攻击不一定能在较弱权限下复现，但它可以揭示机制缺口。反之，在很小预算下未找到攻击，也不能说明扩大预算后仍安全。

白盒与黑盒描述的是知识条件，不是攻击的善恶或现实程度。设计者用完整模型进行白盒测试，是为了排除“防御只依赖攻击者暂时不了解系统”的可能。公开服务还需要黑盒测试，因为只能观察类别、能够观察概率和能够访问内部表示，提供的信息量并不相同。评估中的权限必须真实用于搜索，不能给攻击者白盒访问，却只运行一个没有充分利用梯度的简单方法。

图 17.1 将一次黑盒邮件测试的知识、控制与目标并列声明。只见预测类别，不意味着能改模型参数；只允许改写邮件，也不意味着能写收件箱。查询预算另外的资源条件，需要与这三项一起固定。




图 17.1 威胁模型的三项交叉条件。此教学约定只提供预测类别，允许在保留欺骗目的的前提下改写邮件，目标是使钓鱼邮件被判为正常；最多 20 次查询是声明的资源预算，非实验结果。三个栏位分别描述可见信息、可控对象与成功事件，不能互相推出。换成参数或梯度可见、允许修改数据库或追求信息泄露时，就得到另一份测试约定。

图 17.2 按攻击作用的位置整理这些条件。沿着系统路径定位入口之后，还需说明攻击者能够看见和修改什么，以及何种后果才算成功。

17.2 脆弱性的评估

脆弱性评估要判断：在给定能力和预算下，攻击者能通过哪些路径造成何种损害。输入测试、模型内部分分析与系统审查可以互相补充，并不是只能选择其中一种。以下先统一评估维度、指标与试验程序，再按被测对象展开五类检查：固定模型而改变输入，改变材料并重新运行训练，读取已有模型的内部机制，查询已发布接口，以及运行带权限和状态的完整任务。

这些对象可以属于同一条攻击链。例如，后门可能由训练材料进入参




图 17.2 机器学习系统中的可操纵对象。记录中的内容、更新的参数、发布组件、接口接收的输入与查询、提案指向的行动对象分别形成攻击入口；珊瑚色局部标记指出受影响位置，箭头不表示攻击已经成功。灰色路径表示系统阶段间的联系。同一攻击可以经过多个入口，知识条件、预算与损害目标须另行组合声明。

数，再由特定输入触发，并通过工具执行造成损失。分开评估有助于定位薄弱环节，最终结论仍需回到完整系统。白盒搜索、黑盒试探、组件核查和形式化验证是取得证据的方法；选哪一种，取决于相应对象能提供什么信息以及要判断什么性质。

17.2.1 评估维度与判定标准

评估至少需要区分被测对象、攻击条件与结果指标。输入、模型内部和工具链说明检查哪里；白盒或黑盒、查询次数和污染比例说明在什么能力下检查；攻击成功率、损害和正常任务表现说明检查得到了什么。它们是可以组合的维度，例如同一个输入入口既可以做白盒测试，也可以做黑盒测试，并分别测量不同预算下的损害。

结果指标应回答四类问题：有多少任务被攻破，攻破需要多少修改或查询，成功后影响多大，以及防护使多少正常任务受损。评估覆盖范围则说明这些数字适用于哪些攻击、数据与系统配置。下文的攻击成功率刻画第一项，预算曲线与污染强度刻画第二项，实际状态变化和恢复成本刻画第三项，干净任务效用、误拒率与延迟刻画第四项。它们不能合成一个未经说明的“安全分数”。

可重复的评估程序 基于攻击试验的评估通常包括准备、搜索、执行核验和结果比较四个相互依赖的步骤。准备阶段规定攻击者实际能得到的信息；搜索阶段构造候选攻击；执行核验确认候选满足权限和预算，并观察真实系统；结果比较则把目标达成、损害和正常任务代价分开。后面各类攻击试验共享这套程序，但需要取得的材料、可使用的搜索方法和核验对象有所不同。内部核查和形式化验证还可以直接检查计算结构或约束，不一定经过候选攻击搜索；它们应按各自的证据范围报告结论。

1. 固定被测模型或训练算法的版本、预处理、权限配置及正常任务，保留未攻击时的输出或运行结果。选定攻击入口，并把可修改对象、可见反馈、预算和成功事件写成可检查条件。
2. 只向测试攻击者提供约定的信息，让其在预算内生成候选。记录每次查询与反馈、采用的搜索设置，以及最终提交的对象；改变预算后应作为另一个设置单独报告。
3. 把有效候选交给完整系统执行。既核验修改是否仍属于允许范围，也检查最终输出或状态是否达到攻击目标。对随机系统重复完整过程，保留失败、中止和被拒绝的运行。
4. 按事先定义的试验单位统计成功与损失，并与正常任务对照。改动防御时，先复用原攻击检查已知问题，再开放同预算的新搜索，评价攻击者适应防御后的结果。

例如，若一轮试验允许修改一封邮件、查询二十次，那么统计单位是这次二十次预算内的完整搜索，而不是把二十次调用当成二十个独立任务。若目标是越权归档，只有授权集合外的邮件实际发生状态变化才算该目标成功；生成一句越权建议可以另记为模型行为偏离。

设 n 次完整试验的成功指示为 $s_i \in \{0, 1\}$ ，则经验攻击成功率为 $\widehat{ASR} = n^{-1} \sum_i s_i$ 。这一定义要求先确定哪些试验进入分母。若考察原本能够正确处理的任务，应先确定这组任务，再统计攻击后失败比例；否则正常失败可能被误计为攻击效果。定向攻击还需要检查是否达到指定结果，而不只是产生任意错误。

攻击结果、损害与证据范围 报告成功率时还应给出试验数和估计误差。独立同分布的完整试验可以使用二项比例区间；若同一任务进行了多次相关搜索，则应保留任务这一统计单位，不能靠重复查询制造更大的独立样本量。搜索、挑选攻击和最终比较最好使用职责明确的任务集合，避免只对攻击构造时已经成功的样本报告结果。

成功次数也不等于损失。一次误分类与一次大范围数据泄露可能具有不同严重程度。令随机元素 Ξ 汇总一次完整试验中的任务实例、环境状态和系统内部随机性；若攻击策略自身随机化，其随机数也并入 Ξ 。允许集合 $\mathcal{A}$ 中的每个 a 都是在抽取 Ξ 前固定的策略规则，只能读取威胁模型规定的信息。规则可以在执行过程中依据获准观察的输入和反馈历史选择后续动作，因此“自适应”必须通过策略的信息接口表达，而不是在看到完整试验结果后再逐结果挑选动作。记相应损失为 $L(a, \Xi)$ ，则

$$R_{\text{adv}} = \sup_{a \in \mathcal{A}} \mathbb{E}_{\Xi} [L(a, \Xi)] \quad (17.1)$$

表达规定攻击能力和信息条件下的最不利风险。若攻击者只能预先选择一个固定动作， $\mathcal{A}$ 就应限制为常值策略；若能够观察当前输入或此前查询反馈，则把这些信息加入策略接口。两种设定一般给出不同风险，不能在未修改 $\mathcal{A}$ 时把上确界移入期望。实际测试通常只覆盖 $\mathcal{A}$ 的一部分，因此得到的是已发现风险的证据，而不是未知攻击风险的精确估计。

应同时报告影响范围、恢复成本和正常任务效用。拒绝所有输入可以阻止许多攻击，也会使系统失去服务能力。适当比较是在相同任务和资源条件下，检查防御减少了哪些损害、增加了多少误拒和延迟。

重复尝试进一步影响比较口径。独立采样时，多次查询至少成功一次的概率会随预算增加，相关计算见第 16.5 节；安全测试还需考虑更强的情形：攻击者根据失败反馈更新下一次输入，尝试之间不再独立且成功概率可能改变。此时应以完整攻击过程为试验单位，报告规定预算内是否达到目标。只报告一次调用的失败比例，无法代表允许反复试探的服务条件。

加入防御后，攻击者可能改变策略。例如，关键词过滤会使攻击者改写表达，监控器会成为新的操纵对象。因此应向测试攻击者提供相应的防御知识或试探机会，再比较结果。防御前的攻击集可以作为回归测试，却不能独立代表防御后的安全边界。

形式化认证提供另一类证据：在规定输入集合或程序条件下证明性质成立。其优势是覆盖整个被规定的集合，限制则在于模型、输入空间和权限假设是否覆盖实际系统。第 12.2.2 节的局部变化界只认证相应数值扰动，不能自动覆盖数据投毒或工具越权。

17.2.2 推理输入的评估

普通测试询问一个输入是否预测正确，对抗测试则追问：在允许的修改范围内，是否存在一个仍应得到相同答案、却能使模型出错的输入？Szegedy 等通过输入优化展示了神经网络的这种局部脆弱性，并观察到部分扰动能够迁移到不同网络。由此暴露的问题是，独立测试集上的正确分类，并没有穷尽每个样本周围的决策行为¹。

这一测试需要原始输入及其真实标签、完整预测接口和允许修改集合。白盒设置还提供计算梯度所需的模型信息；黑盒设置则限定返回类别或概率。测试者固定模型，只改变输入，候选必须同时满足修改预算、输入合法性和任务标签保持条件，然后在真实接口上重新预测。

利用输入与输出关系搜索反例 这种脆弱性不必完全归因于复杂的非线性。考虑线性打分 $s(\mathbf{x}) = \mathbf{w}^\top \mathbf{x} + b$ ，其中 $\mathbf{x}, \mathbf{w} \in \mathbb{R}^d$ 。若每个坐标允许改变不超过 ϵ ，取 $\delta_j = \epsilon \operatorname{sign}(w_j)$ ，打分变化就是 $\epsilon \|\mathbf{w}\|_1$ 。即使每个坐标的变化很小，多个方向一致的贡献也可能跨越分类边界。这个计算没有证明所有

¹ C. Szegedy, W. Zaremba, I. Sutskever, J. Bruna, D. Erhan, I. Goodfellow, R. Fergus, *Intriguing Properties of Neural Networks* In arXiv preprint arXiv:1312.6199, 2014

模型都会失败，但说明“单个特征改动小”与“总决策变化小”并不等价。

若要把原本为正的分数压到负侧，可以选择相反的扰动方向。例如，构造二维分类分数 $s(\mathbf{x}) = x_1 - x_2 + 0.05$ ，以正分数预测类别 1。输入 $(0.5, 0.5)$ 的分数为 0.05；在每个坐标允许变化 0.1 的条件下，候选 $(0.4, 0.6)$ 的分数变为 -0.15 ，预测翻转。若任务定义确认这个邻域标签仍为 1，便找到一个有效反例。若正确标签也随输入改变，翻转就不构成这里要测量的攻击成功。

图 17.3 把这一构造放在二维输入平面：虚线方形限定每个坐标的改动预算，箭头给出一个穿过模型边界的候选。找到翻转之后，仍需独立检查输入是否合法、真实任务标签是否保持。




图 17.3 正文二维线性评分器中的预算内扰动。原输入是 $(0.5, 0.5)$ ，分数 0.05；候选 $(0.4, 0.6)$ 的扰动为 $(-0.1, 0.1)$ ，无穷范数 0.1，分数变为 -0.15 。浅色区域区分模型预测，实线为 $s = 0$ ，虚线方形为允许的扰动集合。模型翻转与真实标签改变是不同事件：只有确认邻域真实标签仍为 1 时，该候选才是有效攻击反例。几何与分数均为教学构造，单步搜索不保证任意模型上的攻击成功。

Goodfellow 等据此用局部线性近似构造**快速梯度符号法**（fast gradient sign method, FGSM）。设输入损失梯度为 $\mathbf{g} = \nabla_{\mathbf{x}} \ell(f(\mathbf{x}), y)$ ，在无穷范数约束下，

$$\begin{aligned} \max_{\|\delta\|_{\infty} \leq \epsilon} \mathbf{g}^T \delta &= \epsilon \|\mathbf{g}\|_1, \\ \delta_{\text{FGSM}} &= \epsilon \text{sign}(\mathbf{g}). \end{aligned} \quad (17.2)$$

每个坐标分别选取与梯度同号的端点，就达到线性化目标的最大值；实际

输入还必须满足像素范围等合法性约束。FGSM 的贡献是把输入优化化为一次反向传播，而非证明这一扰动就是原非线性损失的全局最优解²。

对于输入扰动，若允许集合为 Δ ，可以搜索 $\max_{\delta \in \Delta} \ell(f(\mathbf{x} + \delta), y)$ 。在可微条件下，投影梯度搜索反复沿增加损失的方向更新，再投影回 Δ 。它是寻找失败的工具；有限步搜索失败不能认证不存在更好的扰动。

与 FGSM 只在原始输入附近作一次近似不同，多步搜索会在更新后的输入处重新计算梯度。记 $\mathbf{g}^{(t)} = \nabla_{\mathbf{x}^{(t)}} \ell(f(\mathbf{x}^{(t)}), y)$ ，对于允许的输入集合 $\mathbf{X}(\mathbf{x})$ ，无穷范数攻击常用

$$\mathbf{x}^{(t+1)} = \Pi_{\mathbf{X}(\mathbf{x})} [\mathbf{x}^{(t)} + \eta \text{sign}(\mathbf{g}^{(t)})], \quad (17.3)$$

其中 Π 是投影， η 是步长，初始化可以在允许区域内随机选取。这一投影梯度攻击通常称为 PGD 攻击；PGD 沿用了投影梯度下降（projected gradient descent）的缩写，此处则沿增大损失的方向搜索。随机重启有助于探索不同区域；增加迭代次数则细化同一条搜索路径。二者不能相互替代，也不能因某个设置没有继续改善，就认定已经找到最坏输入。

针对防御机制调整搜索 测试时应检查不同初始化、搜索策略和必要的迁移攻击。若防御包含随机性或不可微处理，攻击也需要与这些机制匹配。仅让原有梯度攻击失效可能产生**梯度掩蔽**（gradient masking），即梯度信号变得难以利用，却没有消除真实的决策脆弱性。

搜索失败还可能来自目标函数选择不当。Carlini 与 Wagner 在评估防御蒸馏时，用分类前的打分差构造攻击损失，避免只依赖可能饱和的输出概率。对于目标类别 k ，一个代表性形式是

$$\begin{aligned} \min_{\mathbf{x}' \in [0,1]^d} \quad & \|\mathbf{x}' - \mathbf{x}\|_2^2 + c h_k(\mathbf{x}'), \\ h_k(\mathbf{x}') = \max \quad & \left\{ \max_{j \neq k} [z_j(\mathbf{x}') - z_k(\mathbf{x}')], -\kappa \right\}, \end{aligned} \quad (17.4)$$

其中 z_j 是类别打分， $c > 0$ 协调扰动与攻击目标， $\kappa \geq 0$ 要求目标类别具有相应优势。其评估意义在于：原攻击的数值困难不能充当防御成功的证据，换用合适的搜索目标可能重新发现脆弱性³。

不可微预处理也有类似问题。Athalye 等指出，前向计算中的量化或离散操作可能破坏梯度，却保留可被攻击的决策边界。反向传播近似法在前向仍执行真实防御，在反向用可微近似提供搜索方向；随机防御则可对多次随机变换的损失求平均，估计期望梯度。最终候选输入必须回到真实防御上检验，而不能把近似模型中的成功当作实际成功⁴。

这些搜索改动处在不同层次。FGSM 与 PGD 主要区别在更新一次还是反复更新；CW 重新选择要优化的目标与扰动代价；反向近似和随机变换

² I. J. Goodfellow, J. Shlens, C. Szegedy, *Explaining and Harnessing Adversarial Examples* In arXiv preprint arXiv:1412.6572, 2015

³ N. Carlini, D. Wagner, *Towards Evaluating the Robustness of Neural Networks* In arXiv preprint arXiv:1608.04644, 2017

⁴ A. Athalye, N. Carlini, D. Wagner, *Obfuscated Gradients Give a False Sense of Security: Circumventing Defenses to Adversarial Examples* In Proceedings of the 35th International Conference on Machine Learning, 2018, pp. 274–283

平均解决的是如何为含防御的系统取得可用搜索方向。它们不是互斥的攻击类别：同一测试可以同时使用多步更新、打分差目标和随机变换平均。应根据模型接口和防御机制组合这些选择，并把最终候选送回真实系统判定。

互补搜索与实际输入条件 单个攻击也可能对某种损失或模型结构不敏感。AutoAttack 将不同目标和搜索机制组合起来，包括自动调整步长的梯度攻击、寻找边界的攻击，以及不依赖梯度的查询攻击，用互补性减少手工调参和单一搜索造成的漏检。所谓“免参数调节”指其评估流程预设了相应规则，并不表示测试没有预算，也不表示它对任意防御都自动适用⁵。

在一个构造的测试例子中，若两个攻击分别使 100 个样本中的 12 个和 15 个失败，其中 8 个重合，联合测试发现的是 19 个失败，而不是二者平均的 13.5 个。对于固定的一组攻击，每个样本都必须通过全部搜索才算未被攻破。该结果仍只是“这些攻击没有找到反例”的比例；真正的最坏情况鲁棒准确率不会高于这个比例。

数字空间中的成功也不等于物理环境中的成功。例如，攻击者提交的图案还可能经过拍摄、缩放和压缩，这些过程会改变输入。测试若只在直接送入模型的数组上进行，其结论就只适用于该入口。需要研究物理攻击时，应把成像距离、角度和光照等条件纳入评估；若把它们建模为随机变换，还须说明使用的变换分布为什么能够代表实际条件。

报告结果时应固定扰动集合与预算，在原本预测正确的样本中计算攻击成功率，并按扰动强度展开。对于定向攻击，成功必须是指定类别被输出；对于非定向攻击，才是任意错误均计入。若同一原样本接受多种搜索，按该样本是否至少被一种搜索攻破汇总，而非把各次查询当成独立测试样本。

17.2.3 训练过程的评估

输入攻击只需运行被测模型；训练投毒则必须运行受到污染的学习过程，检查改变训练材料后究竟学到了什么。这里需要同时描述攻击者如何选择污染内容，以及学习者采用什么训练配置。

一次受控试验保留两份相同的训练流程：一份使用原数据，另一份只在威胁模型允许的位置加入或修改污染数据。初始化与超参数采用配对设置，并在多个随机种子下重复；留出评价集既不参与污染构造，也不用于选取最有利的防御结果。攻击者若只知道替代模型，就先在替代训练流程中选择污染内容，再检验它能否迁移到真实训练流程，不能把真实模型梯度暗中加入其知识条件。

若攻击者能改变训练集，优化对象就多了一层。设 $\tilde{D}$ 是允许提交的污

⁵ F. Croce, M. Hein, *Reliable Evaluation of Adversarial Robustness with an Ensemble of Diverse Parameter-Free Attacks* In Proceedings of the 37th International Conference on Machine Learning, 2020, pp. 2206–2216

染数据, D 是正常训练集, $\mathcal{P}$ 规定污染预算。下面先固定一种白盒训练设定: 攻击者知道 D 、真实训练算法、目标损失和随机种子分布, 但在提交 $\tilde{D}$ 时还没有观察到本次训练实际使用的种子。用 $\mathcal{T}(D \cup \tilde{D}; \xi)$ 表示学习者固定的训练算法, 其中 $\xi \sim Q$ 包含按预先规定分布抽取的初始化、数据顺序和其他训练随机性, 则在攻击者选择污染数据时尚未观察 ξ 的设定下, 定向投毒可以写为

$$\begin{aligned} \max_{\tilde{D} \in \mathcal{P}} \quad & \mathbb{E}_{\xi \sim Q} [L_{\text{target}}(\theta_{\mathcal{T}}(\tilde{D}, \xi))], \\ \text{其中} \quad & \theta_{\mathcal{T}}(\tilde{D}, \xi) = \mathcal{T}(D \cup \tilde{D}; \xi). \end{aligned} \quad (17.5)$$

这里 L_{target} 按攻击目标定义, 数值越大表示越接近攻击者希望造成的损害; 它不必等同于正常任务的训练损失。外层选择污染内容, 训练算法映射描述学习者的响应。 $\mathcal{T}$ 必须固定优化器、超参数、停止规则及多解时的选择方式; 确定性训练可以省略对 ξ 的期望。若攻击者能够观察随机种子, 或评价目标采用最坏种子、分位数而非期望, 就需要相应改变信息条件和外层统计量。实际实验应据此报告多个随机种子的分布, 而不能把多值 $\arg \min$ 直接当成一个确定响应。若攻击者只知道替代训练流程, 则应像前段所述, 先在替代流程上构造污染数据, 再用真实的 $\mathcal{T}$ 评价迁移效果, 不能直接使用这里的白盒目标。输入攻击改变一次预测, 投毒则通过学习过程改变后续多次预测。

BadNets 展示了外包训练和模型供应链中的后门风险: 攻击者让带触发模式的样本指向目标类别, 同时维持正常样本上的分类表现。其关键区别在于攻击行为由条件触发, 普通验证集可能根本没有覆盖这一条件。后门也可能随预训练模型进入下游任务, 因此仅检查下游数据来源并不足够⁶。

投毒样本的标签正确, 也不意味着训练过程安全。Poison Frogs 研究的**干净标签投毒** (clean-label poisoning) 保留人工看来合理的标签, 却使污染样本在模型表示中靠近指定目标样本, 诱导分类边界发生不利移动。这类工作说明, 标签复核与训练安全审查保护的是不同环节。其成效依赖表示、训练方式及攻击者对目标的了解, 不能直接推断任意少量数据都能控制任意模型⁷。

BadNets 式后门与干净标签投毒的构造目标不同。前者把“触发模式—目标类别”的关联放入训练, 使多种输入在带触发模式时出现相同偏离; 后者可以只针对一个指定样本, 保持污染样本的表面标签正确, 通过改变表示附近的训练约束影响该目标。二者都修改训练材料, 但前者的验收对象通常是一组触发输入, 后者还需要观察预先指定的目标是否改变判断。采用哪一种构造, 应由威胁模型中的数据权限和目标范围决定。

投毒实验还需要一个没有污染的对照训练过程。若目标样本在正常训练中就经常误判, 不能把污染后的错误全部归因于攻击。应在匹配的训练

⁶ T. Gu, B. Dolan-Gavitt, S. Garg, *BadNets: Identifying Vulnerabilities in the Machine Learning Model Supply Chain* In arXiv preprint arXiv:1708.06733, 2017

⁷ A. Shafahi, W. R. Huang, M. Najibi, O. Suci, C. Studer, T. Dumitras, T. Goldstein, *Poison Frogs! Targeted Clean-Label Poisoning Attacks on Neural Networks* In arXiv preprint arXiv:1804.00792, 2018

配置下比较目标错误率、干净数据性能与不同随机初始化的变动，并分别报告污染比例和污染样本能否实际进入训练集。后门评估需要同时检查触发条件下的目标成功率与无触发条件下的性能；只报告二者之一，会遗漏攻击有效性或隐蔽性。

例如，预先选定目标类别 k 和一组真实标签不为 k 的留出输入，对每个输入分别保留原版本和带触发模式的版本。记录带触发版本被判为 k 的比例、无触发版本的错误率，以及未污染训练模型在相同两组输入上的结果。若污染模型与对照模型只在触发版本上出现明显差异，才有证据把目标偏离与训练污染联系起来。还应按污染预算和触发强度绘制这些指标，而不是只报告最有效的一次训练。

训练数据审查与受控投毒试验应配合使用。前者检查来源、标签和表示分布等可疑线索，后者直接测量这些材料进入学习过程后是否造成损害。若需要比较两种网络结构是否更容易受投毒，应尽量匹配训练数据、算力预算与攻击权限，并让攻击分别适应两种结构；仅比较一次正常训练的准确率无法回答这个问题。对已经交付、无法重新运行其原始训练过程的模型，则转向下面的内部诊断，并说明缺少训练记录造成的证据限制。

17.2.4 模型内部机制的评估

从模型内部评估，是利用计算图、参数、梯度或中间表示寻找薄弱机制，或者验证明确的行为性质。这需要相应的审查权限；只有查询权限时，应报告黑盒结果及其限制，不能假定自己已经完成内部检查。审查者所用的内部权限与真实攻击者可获得的权限应分别报告。

网络层数、参数数量和架构名称本身不能判定模型安全；相同结构配上不同训练数据和参数，可能具有不同边界与后门行为。前面的输入测试观察允许输入能否造成失败，内部分析则帮助解释失败如何产生、搜索是否充分，以及在哪些条件下能够排除失败。二者可以共同处理同一输入攻击；这里单列内部评估，是为了说明它额外提供的机制和验证证据。

计算路径与局部敏感性的诊断 有模型访问权限时，可以检查预处理、各层计算、随机分支和输出变换是否都进入被测路径，再观察梯度或激活变化。局部输入梯度能够提示搜索方向，但单点梯度很小可能只是饱和或梯度掩蔽；它不是整个邻域内的变化上界。比较中间表示也可以发现候选异常，不过仍需回到实际预测验证它是否对应攻击目标。

若怀疑某个组件导致失败，可以在受控副本中替换或暂时移除它，保持其他条件一致，再比较攻击与正常任务。例如，分别检查加入量化前后的真实攻击结果和梯度可用性，可以帮助区分减少脆弱性与仅阻碍搜索。这样的组件比较提供机制证据，不能把修改后模型的安全结论直接当成原模

型的结论。第 15 章的计算过程解释可用于寻找候选机制，安全评估还要补上有效攻击或性质验证。

异常触发机制的诊断 若模型已经取得，是否存在一种触发模式能把多类正常输入推向同一目标？Neural Cleanse 按目标类别反推低复杂度触发模式，并比较不同类别所需触发规模；异常容易到达的类别可能提示后门。随后可以检查相关样本、过滤触发输入或修复模型。它把无法穷举的触发模式搜索转化为一个可操作的诊断问题，但依赖触发结构和异常性假设。输入相关触发器、多个受影响类别，以及本来就存在的类别不对称，都可能削弱这种判据⁸。

触发模式搜索用于诊断已取得模型，不等同于证明发现了真实后门。检验候选触发器时，应在独立输入上测量目标类别出现比例，比较触发前后的行为，并核查其是否满足威胁模型中的可实现条件；怀疑来自训练污染时，还需追踪训练与模型来源。没有找到候选触发器，仅说明本次搜索和触发结构没有发现异常。相关线索如何用于来源审查与参数修复，将分别第 17.3.1 节和第 17.3.2 节讨论。

利用计算结构验证行为约束 内部信息也可以用于形式化验证：把允许输入、网络计算和不希望发生的输出写成约束，检查是否存在满足全部约束的反例。对于含 ReLU 的网络，线性层给出线性等式，ReLU 的激活与不激活状态给出分段约束。Reluplex 研究了这种网络性质验证，将神经网络的计算规则纳入约束求解，而不是只在有限候选输入上试验⁹。

例如，令 $z_j(\mathbf{x}')$ 为类别 j 的打分， y 为原输入 $\mathbf{x}$ 的正确类别， $\mathbf{X}(\mathbf{x})$ 为本次允许输入集合。可以检查是否存在 $\mathbf{x}' \in \mathbf{X}(\mathbf{x})$ 及 $j \neq y$ ，使 $z_j(\mathbf{x}') \geq z_y(\mathbf{x}')$ 。若有经过核验的解，它给出一个竞争类别至少追平正确类别的候选，实际误分类还应按系统的平分处理规则确认；若可靠求解器证明该约束不可满足，就排除了集合内所有这类候选。超时或返回未知，只能保留为未判定，不能计入通过。

另一种做法是沿网络计算传播有效的上下界。若能对每个竞争类别证明整个集合内 $z_y - z_j$ 的下界严格大于零，就能认证分类不变；若下界不大于零，可能只是界太松，仍不等于找到攻击。第 12.2.2 节讨论认证的条件与报告方式。这里使用结构是为了验证具体参数下的具体性质，证明范围不自动扩展到训练投毒、自然语言语义改写或工具执行权限。

17.2.5 查询接口的评估

模型服务的攻击目标可能是复制功能，而非使单次输出错误。Tramèr 等研究了通过预测接口提取模型，说明输出概率等辅助信息可能把查询转化

⁸ B. Wang, Y. Yao, S. Shan, H. Li, B. Viswanath, H. Zheng, B. Y. Zhao, *Neural Cleanse: Identifying and Mitigating Backdoor Attacks in Neural Networks* In 2019 IEEE Symposium on Security and Privacy, 2019, pp. 707–723

⁹ G. Katz, C. Barrett, D. L. Dill, K. Julian, M. J. Kochenderfer, *Reluplex: An Efficient SMT Solver for Verifying Deep Neural Networks* In arXiv preprint arXiv:1702.01135, 2017

为关于参数的方程。例如，已知服务是逻辑回归并返回精确概率 $p(\mathbf{x})$ 时，

$$\log \frac{p(\mathbf{x})}{1 - p(\mathbf{x})} = \mathbf{w}^\top \mathbf{x} + b. \quad (17.6)$$

在预处理已知、概率严格介于零与一且查询设计满秩的理想条件下， $d + 1$ 个独立方程即可确定 $d + 1$ 个未知量。实际接口的舍入、隐藏特征和更复杂模型会改变提取成本；只返回类别也会丢失方程信息，但攻击者仍可通过查询标签训练替代模型¹⁰。

在一维教学例子中，查询 $x = 0$ 得到 $p = 0.5$ ，查询 $x = 1$ 得到 $p = e/(1 + e)$ 。把它们代入式 (17.6)，得到 $b = 0$ 和 $w + b = 1$ ，因而恢复 $w = 1$ 。参数恢复后还要用没有参与求解的新输入核对输出，排除接口假设不成立的情况。这个例子所需的不是“高置信查询”本身，而是精确概率经对数几率变换后给出的线性方程。

若服务只返回类别，就无法从返回值计算这些方程中的对数几率。此时一种测试过程是准备或生成一批允许提交的输入，记录服务返回的标签，以这些输入标签对训练替代分类器，再用剩余预算补充当前替代模型容易分歧的区域。直接方程求解与替代模型训练都是复制功能的手段，区别在于接口提供的信息与采用的模型假设。涉及私人训练内容的提取，则另按上一章的秘密定义与攻击判据评价。

因而，模型窃取测试需要分别测量参数恢复与功能相似性。两个神经网络可以参数不同而预测接近；只检查权重是否一致会漏掉功能复制。相似性还取决于评价分布：正常用户常见输入上的一致率、决策边界附近的一致率和罕见输入上的一致率可能相差很大。查询数量、单次输出信息量和替代模型训练成本共同构成攻击预算。

具体测试可以在规定查询预算内让攻击者训练替代模型，再用独立于查询集的任务输入测量其与原服务的一致率及任务效用，画出预算增加时的变化。若攻击目标是个人信息或训练内容，成功判据则应切换为第 16.2 节的成员推断或内容恢复指标，而不能用功能一致率替代泄露证据。接口上观察到的每一项收益，都应连同输出粒度、查询限制和攻击者已知信息一起报告。

服务可用性还需在接口层单独测试。在隔离环境中固定并发量、单次输入规模、超时和总资源预算，对比正常请求与可疑请求的处理开销，观察正常任务完成率、等待时间和单位任务资源消耗。若延迟来自正常流量同样会触发的容量上限，应如实报告；若少量允许请求就能引发持续异常消耗，则需要定位到相应解析、推理或调度路径。功能复制、私人信息泄露和资源耗尽共享接口，但使用不同的成功与损失指标。

¹⁰ F. Tramèr, F. Zhang, A. Juels, M. K. Reiter, T. Ristenpart, *Stealing Machine Learning Models via Prediction APIs* In arXiv preprint arXiv:1609.02943, 2016




图 17.4 第三方邮件通过上下文影响动作提案的构造情景。用户任务限定邮件 A，外来邮件夹带删除 B 的指令（虚线）；模型可能同时提出归档 A 和删除 B。执行端独立读取可信授权与状态，许可动作改变 A，越权请求被拒后 B 保持不变。图示是防护职责，仍须测试旁路、状态变化和实际损害。

17.2.6 交互与执行链的评估

对于生成系统，还必须把“输出了攻击者想要的内容”和“执行了攻击者想要的行为”分开。Greshake 等研究间接提示注入，展示了第三方内容可以借助检索与工具调用进入模型上下文，使原本的数据来源成为行为操纵入口。这一问题依赖信息来源和授权边界，不能仅靠检查用户直接输入是否包含恶意请求来覆盖¹¹。

图 17.4 把信息来源与行动授权分开。模型生成了越权提案，仍不等于系统已经造成越权损害；这取决于执行链怎样处理提案。

自动化搜索也改变了越狱评估的强度。Zou 等的贪心坐标梯度方法用词元梯度筛选可能降低攻击目标损失的替换候选，再通过实际前向计算选择离散修改；在多个请求和模型上联合优化，可以研究攻击的迁移性。这里的优化目标通常是某种不期望响应的代理目标，代理损失降低仍需由最终行为评估确认。可迁移也不等于能跨越所有模型版本和系统防护¹²。

AgentDojo 把评估从孤立文本推进到带工具和状态的任务环境，同时检查用户任务能否完成，以及攻击者能否诱导指定偏离。这样的设计能够区分真正维持任务能力的防御与一概拒绝工具结果的防御，也便于在同一任务上比较不同注入位置。其结果仍受环境、工具权限和攻击集合约束，不能直接替代真实部署中的授权审计¹³。

测试单位应是一次完整任务过程：在规定位置注入内容，保留模型读取、提出动作、执行端校验和状态变化，分别核对用户任务完成情况与攻击者目标。对同一任务设立无注入对照，再比较信息来源、工具权限和攻击

¹¹ K. Greshake, S. Abdelnabi, S. Mishra, C. Endres, T. Holz, M. Fritz, *Not What You've Signed Up For: Compromising Real-World LLM-Integrated Applications with Indirect Prompt Injection* In arXiv preprint arXiv:2302.12173, 2023

¹² A. Zou, Z. Wang, N. Carlini, M. Nasr, J. Z. Kolter, M. Fredrikson, *Universal and Transferable Adversarial Attacks on Aligned Language Models* In arXiv preprint arXiv:2307.15043, 2023

¹³ E. Debenedetti, J. Zhang, M. Balunović, L. Beurer-Kellner, M. Fischer, F. Tramèr, *AgentDojo: A Dynamic Environment to Evaluate Prompt Injection Attacks and Defenses for LLM Agents* In arXiv preprint arXiv:2406.13352, 2024

击预算变化后的结果。脱离工具执行的文本测试可以检查模型是否受到诱导，却不能独立测量实际越权损失。

沿用归档邮件的任务，可以在测试开始时固定授权邮件集合 A ，并保存收件箱初始状态。让攻击者只能修改一封待读邮件的正文；系统读取后，记录模型提出的归档集合 B 、执行器实际接受的集合 C 和最终邮件状态。 $B \not\subseteq A$ 表示模型提出越权请求， $C \not\subseteq A$ 表示执行端允许越权，两者分别计数。合法任务是否完成，则根据应归档集合是否被正确处理判定。把这三项放在一起，便能区分模型未受诱导、模型受诱导但执行器拦截，以及系统通过全部拒绝维持低攻击成功率这三种情况。

评判器本身也可能误判。关键字匹配会把引用攻击内容与执行攻击混在一起，模型裁判则可能受待评文本影响。对于工具系统，优先检查外部可验证结果，例如是否向未经授权的接收者发送信息、是否修改了越权对象。无法自动判断的案例需要独立复核，并报告判定标准与不确定性，而不是用一个含义含混的安全分数掩盖。

示例 17.1 工具权限改变攻击后果 在一个构造的邮件助手中，同一注入文本让模型提出“归档全部邮件”。系统甲允许模型直接调用无范围限制的归档接口；系统乙只向本次任务暴露经过授权的邮件标识，并在执行端复查。两者可能生成同样的文本，但只有甲能够将该文本转化为越权行动。评估必须区分模型受诱导与系统造成损害。

执行链检查可以把模型与执行器暂时分开。在隔离环境中直接提交正常请求、混入未授权对象的请求和超过数量上限的请求，核对底层状态，再接入受注入影响的模型重测。前一组检查规则本身，后一组检查组合后是否存在旁路。来源标记、工具路由、持久记忆和重试机制也应纳入路径清单，避免只审查一轮模型回答。

17.3 攻击防御与损害控制

评估找出损害路径后，防御要明确改变路径上的哪个环节。本节按干预位置分类：数据与模型来源保护限制有问题的材料进入系统，训练与修复改变模型如何学习或使用这些材料，输入与输出保护约束运行时的信息和资源，执行权限控制限制预测建议能够引发的动作；监测、止损与恢复处理剩余失败。每类措施都有对应的测试对象，也可能与其他措施共同阻断一条攻击链。

例如，一封含恶意指令的邮件可以在输入检查时被识别，也可能被模型正确忽略；即使这两层都失效，独立执行器仍可拒绝越权归档。若邮件已被处理并写入持久状态，则还需要隔离和恢复。分类依据是防护作用的位置与对象，而不是算法名称，不能把“用了对抗训练”作为数据来源、查

询接口和工具权限都安全的证据。

17.3.1 数据与模型来源的保护

数据与模型来源保护决定什么材料可以进入学习或部署。需要检查数据来源、提交主体、标注与变更记录，以及模型文件和配套处理代码的版本。在签名密钥与主体身份的关联可信、验证通过的条件下，数字签名可以支持来源与完整性核验；文件摘要则需要与可信渠道提供的预期值比较，才能检查内容是否发生变化。单独提供一个摘要不能认证发布者身份，来源和完整性核验也不能证明内容没有投毒或后门。

训练准入可以实现为一条独立于模型预测的检查链：记录数据与模型来源，核对允许提交的主体和数量，将新来源暂存审查，再把获准对象纳入可追踪的训练清单。测试这条链时，应分别注入未授权来源、超过配额的提交，以及来源合法但内容受污染的材料。前两类检查权限规则是否执行，后一类才检验内容审查是否发现污染；应同时统计合法材料被拒绝的比例。

内容检查还需寻找来源合法但行为异常的材料。标签抽查可以发现部分错误标注，重复与来源分布检查可以发现异常集中提交，模型表示中的异常分析则试图发现表面标签正常的污染。不同检查对应不同线索，都要与受控污染试验和合法样本误拒情况配合评价。

谱特征方法 (Spectral Signatures) 先用待审数据训练候选模型，再分析同一类别中样本的内部表示：对表示中心化，找到变化最大的方向，再按样本在该方向上的投影大小筛查候选污染，清理后重新训练。Tran 等工作利用了所研究后门在表示空间留下的可分离结构；该依据依赖污染比例和表示分离条件，并不是任何后门都会显现同一种异常¹⁴。

这类筛查需要模型参与，可以把候选训练与清理放在隔离环境中，筛查完成后再决定哪些数据进入后续训练。它属于借助模型表示改进数据质量的循环，不是仅凭入库字段就能完成的检查；候选模型也不能因被用于审查就直接进入生产服务。

第 17.2.4 节的后门诊断可以帮助选择需要审查的模型、样本和触发模式。诊断本身不会清除后门；修复需要明确改变了哪些训练材料、参数或输入处理规则，再重新测量触发条件下的攻击成功率。

异常检测结果应作为调查线索，而不是直接删除一批数据的充分理由。稀有但合法的群体也可能在表示空间中显得异常，这与第 13 章讨论的数据代表性问题相连。修复后既要验证触发行为是否消失，也要检查正常类别和稀有群体的性能，避免把防御代价集中到某些用户。

¹⁴ B. Tran, J. Li, A. Madry, *Spectral Signatures in Backdoor Attacks* In *Advances in Neural Information Processing Systems*, 2018

17.3.2 模型训练与修复

模型层面的防御改变学习规则或已学到的参数。这里按需要抑制的影响分为三种做法：通过对抗训练降低输入操纵的收益，通过聚合规则限制恶意训练更新，通过修复已交付模型削弱被诊断出的异常机制。它们可以组合，但输入扰动训练并不自动解决训练投毒，后门修复也不能代替训练来源审查。

针对输入操纵的训练 对输入扰动，对抗训练把搜索得到的不利样本纳入优化，近似求解最小化最坏损失的问题。Madry 等以鲁棒优化形式连接训练目标和攻击搜索。实际保护范围仍受到允许扰动、内层搜索强度和训练分布的限制¹⁵。

具体训练在每个小批次中交替完成两步：固定当前参数，用第 17.2.2 节的搜索得到允许集合内的高损失输入；固定这些候选输入，再更新模型参数以减小相应损失。以训练分布中的输入与标签取期望，其理想目标为

$$\min_{\theta} \mathbb{E}_{(\mathbf{x}, y)} \left[\sup_{\delta \in \Delta(\mathbf{x})} \ell(f_{\theta}(\mathbf{x} + \delta), y) \right]. \quad (17.7)$$

内层搜索代表攻击者怎样利用当前模型，外层更新代表防御怎样改变这些薄弱点。实际实现通常以有限步搜索近似内层，再将得到的扰动作为当前更新的训练输入；因此模型改变后，需要重新搜索，不能永久复用同一批攻击样本。

这与把固定噪声加入训练集有实质区别：内层搜索随当前模型变化，外层训练不断响应当前薄弱点。但内层搜索太弱时，模型可能只学会抵抗训练中出现的搜索模式。因此，训练攻击与最终评估攻击不应完全相同；还要检查干净样本性能、不同扰动预算及未参与调参的攻击。

第 12.3.1 节的 TRADES 目标（式 (12.6)）进一步明确了正常预测与局部一致性之间的权衡，随机平滑的半径（式 (12.4)）则在条件成立时提供认证。两类方法在这里分别承担经验增强与限定集合内保证的角色。像素范数下的保证不会自动覆盖邮件的语义改写，输入扰动下的训练也不会自动阻止训练投毒；转换攻击面时必须重新检查假设。

针对恶意更新的训练规则 协作训练中，即使参与者身份合法，其提交的更新也可能被操纵。鲁棒聚合用对极端值较不敏感的规则替代直接平均；Yin 等分析了基于逐坐标中位数和截尾均值的分布式学习，给出相应统计与优化条件下的误差结论。这类保证需要匹配恶意参与者比例及正常更新的分布假设¹⁶。

对于参与者提交的向量更新，鲁棒聚合改变的是合并规则。例如逐坐标

¹⁵ A. Madry, A. Makelov, L. Schmidt, D. Tsipras, A. Vladu, *Towards Deep Learning Models Resistant to Adversarial Attacks* In International Conference on Learning Representations, 2018

¹⁶ D. Yin, Y. Chen, K. Ramchandran, P. Bartlett, *Byzantine-Robust Distributed Learning: Towards Optimal Statistical Rates* In Proceedings of the 35th International Conference on Machine Learning, 2018, pp. 5650–5659

中位数在每一维取参与者值的中位数，而不是算术平均。一个构造的一维例子中，五个更新为 0.9, 1.0, 1.1, 8, 9，后两个受攻击者控制；平均值为 4，中位数为 1.1。该例说明，中位数限制了少数极端更新对这一坐标的拉动。它不证明高维聚合后的向量一定有用：各坐标的中位数可能来自不同参与者，合法更新也可能因数据差异而分散。评价应固定参与者数量和恶意比例，比较攻击后的任务损失、正常训练收敛及不同数据群体的损失。

截尾均值则在每一坐标去掉规定数量的最大和最小值，再平均剩余更新。去掉多少必须与威胁假设对应；攻击者若能伪造大量身份，或正常客户端数据差异很大，原来的比例与集中性前提可能失效。第 16.3.2 节的安全聚合隐藏个体更新，而这里的鲁棒聚合需要对更新施加特定运算；组合二者时应明确协议是否支持这些运算，不能把两个名称并列就当成已经得到联合保证。

已训练模型的修复 如果检查发现可信的后门线索，可以清理受污染训练材料并从可信状态重训，也可以尝试修改已交付模型。Fine-Pruning 结合剪枝与干净数据微调：依据干净输入下的激活削减部分低活动神经元，再用干净数据调整剩余参数。Liu 等研究了单独剪枝、单独微调 and 二者组合的效果，以及针对剪枝设计的攻击，说明修复需要考虑攻击者的适应¹⁷。

修复依赖用于诊断和微调的数据是否可信、是否覆盖正常能力，以及异常行为能否与正常机制分离。若可疑机制与有用计算共用表示，剪枝可能损害正常任务，后门也可能在未测试条件下残留。验收应重新运行触发器搜索、已知攻击和保留任务测试；仅让一个已知触发输入失效，不能证明未知触发方式都已消除。

这与第 16.4 节的机器遗忘有关，但目标不同：安全修复要求规定攻击下的异常行为受到限制，数据遗忘则与移除指定记录后的训练结果比较。修改参数可以用于两者，却需要各自的验收标准。若依赖范围无法查清或修复达不到要求，应使用可信数据和可信起点重新训练，而不是继续沿用未经验证的受污染检查点。

17.3.3 推理输入与查询输出的保护

运行时防护可以作用于输入进入模型之前，也可以作用于模型回答交付之后。输入处理限制哪些内容、以什么表示进入计算；输出与查询控制限制观察者得到多少信息、能够尝试多少次。它们通常不修改训练参数，应当在包含这些处理的完整接口上重新评估。

输入检查与可疑请求处置 格式、类型、长度和取值检查可以排除不合法输入，并防止输入突破事先规定的处理范围。对语义合法却具有攻击性的输入，还可以使用异常检测、已知触发模式检测或独立风险分类器，将可

¹⁷ K. Liu, B. Dolan-Gavitt, S. Garg, *Fine-Pruning: Defending Against Backdooring Attacks on Deep Neural Networks* In arXiv preprint arXiv:1805.12185, 2018

疑请求拒绝、转交复核或交给受限服务处理。拒绝并不表示已经正确识别攻击，报告中需要同时统计攻击漏检、正常请求误拒以及被接受请求的剩余风险。

去噪、压缩、量化或文本规范化可以改变攻击实际到达模型时的形式，但也可能删除有用信息或只使梯度难以计算。应把处理过程交给自适应攻击共同测试，使用第 17.2.2 节的近似反向传播、随机变换平均或黑盒搜索检查是否只是梯度掩蔽。对特定输入变换观察到收益，不足以认定所有语义保持的攻击都会被消除。

对于检索和工具返回内容，应保留来源，避免让外部内容直接覆盖系统配置或获得更高权限。过滤已知恶意短语能够处理部分已知模式，角色标记能够为模型提供区分依据，但改写与未知模式仍需检验。外部信息可能同时包含正常任务所需的步骤和恶意要求，因此最终行动仍需要下一小节的独立授权检查。

查询输出与资源配额的控制 查询限制和输出粒度控制可以增加模型窃取或信息提取的成本，也可能影响正常使用。应结合第 16 章判断是否需要输出层面的正式保护，而不能仅以接口隐藏了参数便宣称信息不会泄露。

输出粒度控制直接改变攻击者每次查询得到的约束。对于式 (17.6) 中的逻辑回归，精确概率给出等式；若只发布一个概率区间，攻击者只能知道对数几率落在相应区间；若只返回类别，则只得到决策边界某一侧的信息。限制查询数量进一步约束这些信息能够累积多少。机制的代价是，正常用户也可能失去校准概率或批量处理能力，因此需要按业务用途决定哪些信息应当返回。

可以在同一被测模型上比较精确概率、有限精度概率和仅类别三种接口，分别在相同查询预算下训练替代模型，并在独立输入上测量功能一致率；再固定正常用户的任务，检查输出变化造成的损失。这样能够看到防御究竟减少了接口信息，还是仅拖慢了所有使用者。即使只返回类别，攻击者仍可能通过较多查询近似分类边界，所以评价结果应是一条预算与提取效用的关系，而不是有无概率字段这一布尔判断。

隐私保证与模型保密性也不能互相替代。差分隐私限制单个参与者对发布结果的影响，却允许发布本身包含有价值的总体规律；攻击者仍可能近似复制这些规律。反过来，隐藏模型结构也不能证明训练数据受到保护。接口设计必须先明确要保护个人信息、模型商业价值，还是对安全决策规则的了解程度，再选择相应评价目标。

控制措施实施后，应按第 17.2.5 节重新比较相同预算下的提取收益，并测量正常用户被限流、输出精度下降或响应延迟的代价。若攻击者可以使用多个账户或多次会话，预算控制还需与威胁模型中的身份边界一致；单一会话的限制并不自动约束整个攻击过程。

对资源消耗还可以限制单次输入规模、并发请求、生成长度、工具调用次数和任务总时长，并在队列中隔离不同租户。限制应作用于完整任务和可识别的主体，而非仅某次调用；否则一次任务中的重试或多会话累积仍可能超出原定预算。测试需要同时观察是否抑制异常消耗，以及长文本、批处理等正常需求是否受到不合理限制。

17.3.4 行动执行中的权限控制

行为约束中的执行干预把模型输出限制为动作提案，再由独立执行器核验授权对象、参数与当前状态，具体机制见第 14.4.6 节。对抗安全进一步检查攻击者能否绕过这些条件。安全结论不能停留在“存在权限检查”，而要覆盖攻击者能够控制的身份、内容、调用顺序和反馈。

最小权限仍是测试的起点：摘要任务不应获得删除能力，读取指定文档不应获得浏览全部私人目录的权限。攻击者可能伪造对象标识、把越权对象藏入批量参数、利用检查与执行之间的状态变化，或借多个账户和连续低权限动作绕过单次上限。沙箱和结构化参数只有在这些路径都受约束时才有明确作用，名称本身不能说明隔离范围。

多层防御应检查失效是否独立。如果输入过滤、行为评判和最终授权都依赖同一个容易被相同文本操纵的模型，增加层数未必显著减少风险。防御设计需要追踪各层共享的信息与弱点。

测试时应直接向执行器提交伪造主体、越权对象、重复对象、超过数量限制的批量请求及状态已经改变的请求，再把同样条件放回受提示注入影响的完整交互。前一组检查授权规则本身，后一组检查模型、路由和执行器组合后是否存在旁路。每次测试都要核对底层状态和正常任务完成情况；错误文本被拒绝只是行为结果，只有越权对象始终没有发生状态变化，才支持执行边界在相应攻击条件下有效。

检索增强系统还应保留来源信息。来自网页的操作建议可以成为用户任务所需的事实材料，却不应因此修改工具权限。把文本放入引号或标为“不可信”，有助于训练和推理时区分内容角色，但这些仍是模型需要正确理解的信号。真正限制损害的条件是，忽略这些信号时也无法越过外部授权检查。涉及不可逆动作时，复核界面还要显示具体对象和后果，让复核者能够判断所批准的究竟是什么。

17.3.5 攻击监测与损害恢复

事前防护仍可能被突破，运行中的检测与应急处置需要衔接。可以监测异常查询密度、资源消耗、工具调用范围、连续拒绝、模型版本变化和外部信息流向，再结合实际状态与独立记录判断是否需要响应。这些信号提供异常线索，不能只凭模型自报“没有受到攻击”确认安全；误报与漏报也

应通过演练测量。

检测到高风险迹象后，可以暂停相关任务与后续工具调用、撤销会话凭据、隔离可疑数据和模型版本，并将服务切换到受限功能或经过验证的版本。不同动作应按损害传播位置选择：正在外发信息时要及时关闭出口，模型已受污染时还要停止相关版本继续产生决策。只拦住当前输入，不能清除训练参数或持久记忆中的污染。

有些攻击只能在造成部分影响后被发现。限制单次动作规模、保存必要恢复状态、及时撤销权限和停止后续动作，可以减少损失范围。恢复机制也需要测试：能够恢复文件不意味着能够收回已经发送的信息，能够停止后续动作也不能撤销此前不可逆操作。

恢复演练可以在隔离测试环境中记录初始状态，执行一条会错误修改邮件标签的构造轨迹，在规定时刻触发检测，再观察停止后续动作、撤销权限和恢复标签是否成功。测量应包括检测至停止的时间、停止前影响了多少对象、恢复了多少状态，以及仍无法恢复的损失。对已经发送到外部的信息，测试结果只能记录进一步传播是否受限，不能把本地删除日志当成收回信息。这个过程检验的是发现失效后系统还能控制什么，而不是重新评价最初的攻击是否成功。

恢复还涉及证据保全。系统需要记录足够的信息来区分模型错误、外部注入与授权配置问题，但日志本身可能包含敏感输入，应按第16章的原则控制访问与保留范围。发现攻击后若只替换模型而不关闭同一注入入口，风险可能继续存在；若只删除恶意文档而不检查已经写入的记忆和派生状态，也可能留下后续触发条件。恢复范围应沿实际信息传播路径确定。

防御完成后应回到第17.2节复测正常任务、已知攻击和针对新防御的攻击。结论应写为在指定能力与预算下哪些损害受到限制，并说明尚未覆盖的条件。

止损与恢复后的重新开放也需要判据。对可疑版本或入口，应确认处置范围、修复验证结果和仍未覆盖的攻击条件，再逐步恢复权限并继续观察。防御的共同验收条件是：在相同威胁模型下减少了哪些损害，正常任务付出了什么代价，以及失效后能在多长时间内停止传播；不是部署的检测器或过滤层数越多就越安全。

图17.5把训练准入、模型复核、运行接口、独立授权与监测恢复放回具体传播路径。来源检查可以拒绝未获准的材料，却不能保证发现合法来源的污染；合法格式的注入也可能通过输入检查和模型，最终授权仍须独立守住行动对象。恢复则处理已经发生的影响，不与事前阻断混为一项。




图 17.5 纵深防御的职责与阻断位置。训练路径中，未授权来源在准入处停止，发现异常的候选模型暂不发布；通过来源检查不证明内容无污染。运行路径中，格式合法的外部注入仍可能到达模型并形成归档 B 的提案，独立授权拒绝该越权对象，B 状态不变。底部监测依据独立记录与底层状态，失效后暂停、撤权并恢复可逆状态；已经外发的信息不能据此收回。图示阻断是相应检查触发时的响应，不保证所有攻击都会被发现，也不假定各层失效独立。

17.4 前沿研究

智能体的风险来自动态交互。外部内容既可能包含有用操作信息，也可能包含试图扩展权限的指令，简单地忽略全部外部指令会降低任务能力。评估因此需要同时考察正常信息使用和恶意操纵，而不能只在孤立提示上比较是否拒答。

AgentDyn 围绕动态任务、有用第三方指令和更复杂的用户目标构造评测，讨论安全性与过度防御之间的取舍。这是对评估情境的扩展，论文中的结果仍受所测任务、攻击与防御集合限制¹⁸。

它所指向的困难可以从前面的邮件例子看出：一封可信业务邮件可能包含完成任务必需的步骤，但其中也可能夹带超出授权的操作。完全忽略步骤会使任务失败，全部照做又会扩大攻击面。研究重点因而从“文本中有没有命令”转向“哪一部分内容在何种来源与权限条件下可以影响哪个动作”。评估需要保留这种混合情境，而非让正常任务与恶意文本在表面形式上容易区分。

另一个变化是攻击者能够长期适应防御。静态测试集容易逐渐成为训练材料，使分数改善与防护能力改善难以区分。具有明确预算的自动化红队测试可以持续提出新候选，但候选生成器本身也有搜索偏好。可信证据需要结合多种攻击来源、保留未用于防御调优的任务，并记录攻击者获得了哪些反馈；仅增加生成次数不保证覆盖新的失败机制。

多模态内容、长期记忆和工具组合进一步扩大攻击面。某段内容可能在读入时无害，却在后续被重新当作指令；多个低权限操作也可能组合出较大损害。未来研究需要从单次成功率扩展到行为链、状态变化和可恢复性，并让攻击者能够针对完整协议调整策略。

17.5 本章小结

回到章首的邮件系统，抵御有目的的操纵，需要沿输入选择、训练操纵、信息获取和行为诱导的路径，检查系统是否偏离任务与安全要求。攻击类型说明采取什么操作，完整性、机密性和可用性说明造成什么损害，威胁模型则限定攻击者能看见、改变和尝试多少。模型出错、提出越权动作与系统真正造成损失，需要分别记录。

评估中，输入搜索寻找具体反例，受控训练比较检验污染如何改变模型，内部分析定位机制或验证规定性质，查询试验测量信息与资源暴露，完整交互测试核对权限和状态变化。这些证据共同说明系统在哪些条件下脆弱；架构名称、单次攻击失败或一张干净测试成绩单都不足以替代它们。攻击成功率还应与预算、损害、正常任务代价及证据覆盖范围一起解释。

防御沿同一信息和行动路径布置。来源审查不能消除已进入参数的后

¹⁸ H. Li, R. Wen, S. Shi, N. Zhang, Y. Vorobeychik, C. Xiao, *AgentDyn: Are Your Agent Security Defenses Deployable in Real-World Dynamic Environments?* In arXiv preprint arXiv:2602.03117, 2026

门，模型训练不能代替查询配额与执行授权，运行时过滤也不能自动修复持久污染。选择措施时，应根据已发现的薄弱位置组合数据、模型、接口与执行端保护，并让攻击者针对新防御重新搜索。监测和恢复进一步决定突破发生后还能控制多少损失；信息已经外泄与可撤销的状态修改，具有不同的恢复边界。

目标对齐与行为约束还要处理没有外部攻击时出现的行为偏离，相关讨论见第 14 章。本章进一步加入有目的的操纵：攻击者可能利用预测误差、环境变化、信息泄露或权限缺口，使既有保护失效。因此，安全验证需要把前面各章的性质放回同一个系统中，检查它们在攻击者能力范围内是否仍然成立；一项性质的改进不能代替对其余损害路径的检查。

延伸阅读 Madry 等人的鲁棒优化与 Athalye 等人的自适应攻击研究，适合继续理解防御训练和攻击评估为何必须配套。前者把允许扰动写入训练目标，后者说明梯度不可用可能只是搜索受阻；阅读时应区分经验搜索失败与形式化认证¹⁹。

对于具有检索和工具权限的系统，可继续阅读间接提示注入与 Agent-Dojo。前者追踪第三方内容怎样进入行为链，后者同时评价用户任务和攻击目标；两者都要求把模型输出、执行器接受的动作和最终状态分开记录²⁰。

¹⁹ A. Madry, A. Makelov, L. Schmidt, D. Tsipras, A. Vladu, *Towards Deep Learning Models Resistant to Adversarial Attacks* In International Conference on Learning Representations, 2018; A. Athalye, N. Carlini, D. Wagner, *Obfuscated Gradients Give a False Sense of Security: Circumventing Defenses to Adversarial Examples* In Proceedings of the 35th International Conference on Machine Learning, 2018, pp. 274–283

²⁰ K. Greshake, S. Abdelnabi, S. Mishra, C. Endres, T. Holz, M. Fritz, *Not What You've Signed Up For: Compromising Real-World LLM-Integrated Applications with Indirect Prompt Injection* In arXiv preprint arXiv:2302.12173, 2023; E. DeBenedetti, J. Zhang, M. Balunović, L. Beurer-Kellner, M. Fischer, F. Tramèr, *AgentDojo: A Dynamic Environment to Evaluate Prompt Injection Attacks and Defenses for LLM Agents* In arXiv preprint arXiv:2406.13352, 2024



参考文献

- M. Abadi, A. Chu, I. Goodfellow, H. B. McMahan, I. Mironov, K. Talwar, L. Zhang, *Deep Learning with Differential Privacy* In Proceedings of the 2016 ACM SIGSAC Conference on Computer and Communications Security, 2016, pp. 308–318.
- J. Adebayo, J. Gilmer, M. Muelly, I. Goodfellow, M. Hardt, B. Kim, *Sanity Checks for Saliency Maps* In arXiv preprint arXiv:1810.03292, 2018.
- A. Agarwal, A. Beygelzimer, M. Dudík, J. Langford, H. Wallach, *A Reductions Approach to Fair Classification* In Proceedings of the 35th International Conference on Machine Learning, 2018, pp. 60–69.
- C. C. Aggarwal, *Recommender Systems*, Springer, 2016.
- M. Alshiekh, R. Bloem, R. Ehlers, B. Könighofer, S. Niekum, U. Topcu, *Safe Reinforcement Learning via Shielding* In Proceedings of the AAAI Conference on Artificial Intelligence, 2018.
- A. Angelopoulos, S. Bates, A. Fisch, L. Lei, T. Schuster, *Conformal Risk Control* In International Conference on Learning Representations, 2024.
- A. N. Angelopoulos, S. Bates, *A Gentle Introduction to Conformal Prediction and Distribution-Free Uncertainty Quantification* In arXiv preprint arXiv:2107.07511, 2022.
- D. W. Apley, J. Zhu, *Visualizing the Effects of Predictor Variables in Black Box Supervised Learning Models* In Journal of the Royal Statistical Society Series B: Statistical Methodology, 2020, vol. 82, no. 4, pp. 1059–1086.
- M. Arjovsky, L. Bottou, I. Gulrajani, D. Lopez-Paz, *Invariant Risk Minimization* In arXiv preprint arXiv:1907.02893, 2019.
- S. Arora, N. Cohen, W. Hu, Y. Luo, *Implicit Regularization in Deep Matrix Factorization* In Advances in Neural Information Processing Systems, 2019.
- S. Arora, S. S. Du, W. Hu, Z. Li, R. Wang, *Fine-Grained Analysis of Optimization and Generalization for Overparameterized Two-Layer Neural Networks* In Proceedings of the 36th International Conference on Machine Learning, 2019, pp. 322–332.

- A. Asgari, H. Wu, A. Naziri, M. Kollahdouzi, L. Seyyed-Kalantari, *Quantifying Metric and Model Agreement in Bias Evaluation of Large Language Models* In Proceedings of the 64th Annual Meeting of the Association for Computational Linguistics, 2026, pp. 16868–16933.
- A. Athalye, N. Carlini, D. Wagner, *Obfuscated Gradients Give a False Sense of Security: Circumventing Defenses to Adversarial Examples* In Proceedings of the 35th International Conference on Machine Learning, 2018, pp. 274–283.
- I. Attias, S. Hanneke, A. Ramaswami, *Sample Compression Scheme Reductions* In Proceedings of the 36th International Conference on Algorithmic Learning Theory, 2025, pp. 134–162.
- Y. Bai, S. Kadavath, S. Kundu, A. Askell, J. Kernion, A. Jones, A. Chen, A. Goldie, A. Mirhoseini, C. McKinnon, C. Chen, C. Olsson, C. Olah, D. Hernandez, D. Drain, D. Ganguli, D. Li, E. Tran-Johnson, E. Perez, J. Kerr, J. Mueller, J. Ladish, J. Landau, K. Ndousse, K. Lukosuite, L. Lovitt, M. Sellitto, N. Elhage, N. Schiefer, N. Mercado, N. DasSarma, R. Lasenby, R. Larson, S. Ringer, S. Johnston, S. Kravec, S. El Showk, S. Fort, T. Lanham, T. Telleen-Lawton, T. Conerly, T. Henighan, T. Hume, S. R. Bowman, Z. Hatfield-Dodds, B. Mann, D. Amodei, N. Joseph, S. McCandlish, T. Brown, J. Kaplan, *Constitutional AI: Harmlessness from AI Feedback* In arXiv preprint arXiv:2212.08073, 2022.
- R. F. Barber, E. J. Candès, A. Ramdas, R. J. Tibshirani, *The Limits of Distribution-Free Conditional Predictive Inference* In arXiv preprint arXiv:1903.04684, 2020.
- P. L. Bartlett, *For Valid Generalization the Size of the Weights is More Important than the Size of the Network* In Advances in Neural Information Processing Systems, 1996.
- P. L. Bartlett, D. J. Foster, M. J. Telgarsky, *Spectrally-Normalized Margin Bounds for Neural Networks* In Advances in Neural Information Processing Systems 30, 2017.
- P. L. Bartlett, N. Harvey, C. Liaw, A. Mehrabian, *Nearly-tight VC-dimension and Pseudodimension Bounds for Piecewise Linear Neural Networks* In Journal of Machine Learning Research, 2019, vol. 20, no. 63, pp. 1–17.
- P. L. Bartlett, P. M. Long, G. Lugosi, A. Tsigler, *Benign Overfitting in Linear Regression* In Proceedings of the National Academy of Sciences, 2020, vol. 117, no. 48, pp. 30063–30070.
- P. L. Bartlett, S. Mendelson, *Rademacher and Gaussian Complexities: Risk Bounds and Structural Results* In Journal of Machine Learning Research, 2002, vol. 3, pp. 463–482.

- E. B. Baum, D. Haussler, *What Size Net Gives Valid Generalization?* In Advances in Neural Information Processing Systems, 1988.
- M. Belkin, D. Hsu, S. Ma, S. Mandal, *Reconciling Modern Machine-Learning Practice and the Classical Bias–Variance Trade-Off* In Proceedings of the National Academy of Sciences, 2019, vol. 116, no. 32, pp. 15849–15854.
- S. Ben-David, J. Blitzer, K. Crammer, A. Kulesza, F. Pereira, J. W. Vaughan, *A Theory of Learning from Different Domains* In Machine Learning, 2010, vol. 79, pp. 151–175.
- S. Ben-David, T. Lu, T. Luu, D. Pál, *Impossibility Theorems for Domain Adaptation* In Proceedings of the Thirteenth International Conference on Artificial Intelligence and Statistics, 2010, pp. 129–136.
- J. C. Bezdek, R. Ehrlich, W. Full, *FCM: The Fuzzy c-Means Clustering Algorithm* In Computers & Geosciences, 1984, vol. 10, no. 2-3, pp. 191–203.
- A. Bifet, R. Gavaldà, *Learning from Time-Changing Data with Adaptive Windowing* In Proceedings of the 2007 SIAM International Conference on Data Mining, 2007, pp. 443–448.
- C. M. Bishop, *Pattern Recognition and Machine Learning*, Springer, 2006, 1st ed.
- C. M. Bishop, H. Bishop, *Deep Learning: Foundations and Concepts*, Springer, 2024.
- D. M. Blei, A. Y. Ng, M. I. Jordan, *Latent Dirichlet Allocation* In Journal of Machine Learning Research, 2003, vol. 3, pp. 993–1022.
- K. Bonawitz, V. Ivanov, B. Kreuter, A. Marcedone, H. B. McMahan, S. Patel, D. Ramage, A. Segal, K. Seth, *Practical Secure Aggregation for Privacy-Preserving Machine Learning* In Proceedings of the 2017 ACM SIGSAC Conference on Computer and Communications Security, 2017.
- B. Bordelon, A. Atanasov, C. Pehlevan, *A Dynamical Model of Neural Scaling Laws* In arXiv preprint arXiv:2402.01092, 2024.
- B. Bordelon, A. Atanasov, C. Pehlevan, *How Feature Learning Can Improve Neural Scaling Laws* In International Conference on Learning Representations, 2025.
- L. Bourtole, V. Chandrasekaran, C. A. Choquette-Choo, H. Jia, A. Travers, B. Zhang, D. Lie, N. Papernot, *Machine Unlearning* In 2021 IEEE Symposium on Security and Privacy, 2021.
- O. Bousquet, A. Elisseeff, *Stability and Generalization* In Journal of Machine Learning Research, 2002, vol. 2, pp. 499–526.
- O. Bousquet, Y. Klochkov, N. Zhivotovskiy, *Sharper Bounds for Uniformly Stable Algorithms* In Proceedings of the Thirty Third Conference on Learning Theory, 2020, pp. 610–626.

- T. Bricken, A. Templeton, J. Batson, B. Chen, A. Jermyn, T. Conerly, N. Turner, C. Anil, C. Denison, A. Askell, R. Lasenby, Y. Wu, S. Kravec, N. Schiefer, T. Maxwell, N. Joseph, Z. Hatfield-Dodds, A. Tamkin, K. Nguyen, B. McLean, J. E. Burke, T. Hume, S. Carter, T. Henighan, C. Olah, *Towards Monosemanticity: Decomposing Language Models With Dictionary Learning* In Transformer Circuits Thread, 2023.
- G. W. Brier, *Verification of Forecasts Expressed in Terms of Probability* In Monthly Weather Review, 1950, vol. 78, no. 1, pp. 1–3.
- T. B. Brown, B. Mann, N. Ryder, M. Subbiah, J. Kaplan, P. Dhariwal, A. Nee-lakantan, P. Shyam, G. Sastry, A. Askell, S. Agarwal, A. Herbert-Voss, G. Krueger, T. Henighan, R. Child, A. Ramesh, D. M. Ziegler, J. Wu, C. Winter, C. Hesse, M. Chen, E. Sigler, M. Litwin, S. Gray, B. Chess, J. Clark, C. Berner, S. McCandlish, A. Radford, I. Sutskever, D. Amodei, *Language Models Are Few-Shot Learners* In Advances in Neural Information Processing Systems 33, 2020, pp. 1877–1901.
- N. Brukhim, D. Carmon, I. Dinur, S. Moran, A. Yehudayoff, *A Characterization of Multiclass Learnability* In Proceedings of the 63rd Annual Symposium on Foundations of Computer Science, 2022, pp. 943–955.
- Y. Bu, S. Zou, V. V. Veeravalli, *Tightening Mutual Information-Based Bounds on Generalization Error* In IEEE Journal on Selected Areas in Information Theory, 2020, vol. 1, no. 1, pp. 121–130.
- J. Buolamwini, T. Gebru, *Gender Shades: Intersectional Accuracy Disparities in Commercial Gender Classification* In Proceedings of the 1st Conference on Fairness, Accountability and Transparency, 2018, pp. 77–91.
- C. Burns, P. Izmailov, J. H. Kirchner, B. Baker, L. Gao, L. Aschenbrenner, Y. Chen, A. Ecoffet, M. Joglekar, J. Leike, I. Sutskever, J. Wu, *Weak-to-Strong Generalization: Eliciting Strong Capabilities With Weak Supervision* In arXiv preprint arXiv:2312.09390, 2023.
- Y. Cao, J. Yang, *Towards Making Systems Forget with Machine Unlearning* In 2015 IEEE Symposium on Security and Privacy, 2015.
- N. Carlini, S. Chien, M. Nasr, S. Song, A. Terzis, F. Tramer, *Membership Inference Attacks From First Principles* In arXiv preprint arXiv:2112.03570, 2022.
- N. Carlini, F. Tramer, E. Wallace, M. Jagielski, A. Herbert-Voss, K. Lee, A. Roberts, T. Brown, D. Song, U. Erlingsson, A. Oprea, C. Raffel, *Extracting Training Data from Large Language Models* In 30th USENIX Security Symposium, 2021.
- N. Carlini, D. Wagner, *Towards Evaluating the Robustness of Neural Networks* In arXiv preprint arXiv:1608.04644, 2017.

- R. Caruana, *Multitask Learning* In Machine Learning, 1997, vol. 28, pp. 41–75.
- C. Chen, O. Li, C. Tao, A. J. Barnett, J. Su, C. Rudin, *This Looks Like That: Deep Learning for Interpretable Image Recognition* In Advances in Neural Information Processing Systems, 2019.
- T. Chen, S. Kornblith, M. Norouzi, G. Hinton, *A Simple Framework for Contrastive Learning of Visual Representations* In Proceedings of the 37th International Conference on Machine Learning, 2020, pp. 1597–1607.
- P. F. Christiano, J. Leike, T. B. Brown, M. Martic, S. Legg, D. Amodei, *Deep Reinforcement Learning from Human Preferences* In Advances in Neural Information Processing Systems 30, 2017, pp. 4299–4307.
- J. Cohen, E. Rosenfeld, Z. Kolter, *Certified Adversarial Robustness via Randomized Smoothing* In Proceedings of the 36th International Conference on Machine Learning, 2019, pp. 1310–1320.
- R. Colomboni, E. Esposito, A. Paudice, *An Improved Uniform Convergence Bound with Fat-Shattering Dimension* In arXiv preprint arXiv:2307.06644, 2023.
- C. Cortes, V. Vapnik, *Support-Vector Networks* In Machine Learning, 1995, vol. 20, no. 3, pp. 273–297.
- T. M. Cover, *Geometrical and Statistical Properties of Systems of Linear Inequalities with Applications in Pattern Recognition* In IEEE Transactions on Electronic Computers, 1965, vol. EC-14, no. 3, pp. 326–334.
- F. Croce, M. Hein, *Reliable Evaluation of Adversarial Robustness with an Ensemble of Diverse Parameter-Free Attacks* In Proceedings of the 37th International Conference on Machine Learning, 2020, pp. 2206–2216.
- A. D’Amour, K. Heller, D. Moldovan, B. Adlam, B. Alipanahi, A. Beutel, C. Chen, J. Deaton, J. Eisenstein, M. D. Hoffman, F. Hormozdiari, N. Houlsby, S. Hou, G. Jerfel, A. Karthikesalingam, M. Lucic, Y. Ma, C. McLean, D. Mincu, A. Mitani, A. Montanari, Z. Nado, V. Natarajan, C. Nielson, T. F. Osborne, R. Raman, K. Ramasamy, R. Sayres, J. Schrouff, M. Seneviratne, S. Sequeira, H. Suresh, V. Veitch, M. Vladymyrov, X. Wang, K. Webster, S. Yadlowsky, T. Yun, X. Zhai, D. Sculley, *Underspecification Presents Challenges for Credibility in Modern Machine Learning* In arXiv preprint arXiv:2011.03395, 2020.
- A. Daniely, S. Sabato, S. Ben-David, S. Shalev-Shwartz, *Multiclass Learnability and the ERM Principle* In Journal of Machine Learning Research, 2015, vol. 16, no. 72, pp. 2377–2404.

- J. De Houwer, D. Barnes-Holmes, A. Moors, *What Is Learning? On the Nature and Merits of a Functional Definition of Learning* In *Psychonomic Bulletin & Review*, 2013, vol. 20, no. 4, pp. 631–642.
- E. Debenedetti, J. Zhang, M. Balunović, L. Beurer-Kellner, M. Fischer, F. Tramèr, *AgentDojo: A Dynamic Environment to Evaluate Prompt Injection Attacks and Defenses for LLM Agents* In arXiv preprint arXiv:2406.13352, 2024.
- L. Defilippis, Y. Xu, J. Girardin, V. Erba, E. Troiani, L. Zdeborová, B. Loureiro, F. Krzakala, *Scaling Laws and Spectra of Shallow Neural Networks in the Feature Learning Regime* In *International Conference on Learning Representations*, 2026.
- M. P. Deisenroth, A. A. Faisal, C. S. Ong, *Mathematics for Machine Learning*, Cambridge University Press, 2020.
- V. Delle Rose, A. Kozachinskiy, C. Rojas, T. Steifer, *Find a Witness or Shatter: The Landscape of Computable PAC Learning* In *Proceedings of the 36th Conference on Learning Theory*, 2023, pp. 511–524.
- B. DeMoss, S. Sapora, J. Foerster, N. Hawes, I. Posner, *The Complexity Dynamics of Grokking* In *Physica D: Nonlinear Phenomena*, 2025, vol. 482, pp. 134859.
- J. Devlin, M.-W. Chang, K. Lee, K. Toutanova, *BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding* In *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*, 2019, pp. 4171–4186.
- I. S. Dhillon, Y. Guan, B. Kulis, *Kernel k-Means, Spectral Clustering and Normalized Cuts* In *Proceedings of the Tenth ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 2004, pp. 551–556.
- L. Dinh, R. Pascanu, S. Bengio, Y. Bengio, *Sharp Minima Can Generalize for Deep Nets* In *Proceedings of the 34th International Conference on Machine Learning*, 2017, pp. 1019–1028.
- F. Doshi-Velez, B. Kim, *Towards A Rigorous Science of Interpretable Machine Learning* In arXiv preprint arXiv:1702.08608, 2017.
- C. Dwork, M. Hardt, T. Pitassi, O. Reingold, R. Zemel, *Fairness Through Awareness* In *Proceedings of the 3rd Innovations in Theoretical Computer Science Conference*, 2012.
- C. Dwork, A. Roth, *The Algorithmic Foundations of Differential Privacy* In *Foundations and Trends in Theoretical Computer Science*, 2014, vol. 9, no. 3–4, pp. 211–407.

- M. Ester, H.-P. Kriegel, J. Sander, X. Xu, *A Density-Based Algorithm for Discovering Clusters in Large Spatial Databases with Noise* In Proceedings of the Second International Conference on Knowledge Discovery and Data Mining, 1996, pp. 226–231.
- S. Farquhar, J. Kossen, L. Kuhn, Y. Gal, *Detecting Hallucinations in Large Language Models Using Semantic Entropy* In Nature, 2024, vol. 630, pp. 625–630.
- C. Finn, P. Abbeel, S. Levine, *Model-Agnostic Meta-Learning for Fast Adaptation of Deep Networks* In Proceedings of the 34th International Conference on Machine Learning, 2017, pp. 1126–1135.
- Y. Gal, Z. Ghahramani, *Dropout as a Bayesian Approximation: Representing Model Uncertainty in Deep Learning* In Proceedings of the 33rd International Conference on Machine Learning, 2016, pp. 1050–1059.
- Y. Gal, R. Islam, Z. Ghahramani, *Deep Bayesian Active Learning with Image Data* In Proceedings of the 34th International Conference on Machine Learning, 2017, pp. 1183–1192.
- Y. Ganin, E. Ustinova, H. Ajakan, P. Germain, H. Larochelle, F. Laviolette, M. Marchand, V. Lempitsky, *Domain-Adversarial Training of Neural Networks* In Journal of Machine Learning Research, 2016, vol. 17, no. 59, pp. 1–35.
- L. Gao, J. Schulman, J. Hilton, *Scaling Laws for Reward Model Overoptimization* In arXiv preprint arXiv:2210.10760, 2022.
- T. Gebru, J. Morgenstern, B. Vecchione, J. W. Vaughan, H. Wallach, H. Daumé III, K. Crawford, *Datasheets for Datasets* In arXiv preprint arXiv:1803.09010, 2021.
- Y. Geifman, R. El-Yaniv, *SelectiveNet: A Deep Neural Network with an Integrated Reject Option* In Proceedings of the 36th International Conference on Machine Learning, 2019, pp. 2151–2159.
- R. Geirhos, J.-H. Jacobsen, C. Michaelis, R. Zemel, W. Brendel, M. Bethge, F. A. Wichmann, *Shortcut Learning in Deep Neural Networks* In Nature Machine Intelligence, 2020.
- P. Germain, A. Habrard, F. Laviolette, E. Morvant, *An Improvement to the Domain Adaptation Bound in a PAC-Bayesian Context* In arXiv preprint arXiv:1501.03002, 2015.
- A. Géron, *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow*, O'Reilly Media, 2022, 3rd ed.
- I. Gibbs, E. Candès, *Adaptive Conformal Inference Under Distribution Shift* In arXiv preprint arXiv:2106.00170, 2021.
- I. Goodfellow, Y. Bengio, A. Courville, *Deep Learning*, MIT Press, 2016.

- I. J. Goodfellow, J. Shlens, C. Szegedy, *Explaining and Harnessing Adversarial Examples* In arXiv preprint arXiv:1412.6572, 2015.
- Google, *Recommendation Systems Overview*, Aug. 25, 2025, URL: <https://developers.google.com/machine-learning/recommendation/overview/types>.
- P. Gourdeau, T. Lechner, R. Urner, *On the Computability of Multiclass PAC Learning* In arXiv preprint arXiv:2502.06089, 2025.
- K. Greshake, S. Abdelnabi, S. Mishra, C. Endres, T. Holz, M. Fritz, *Not What You've Signed Up For: Compromising Real-World LLM-Integrated Applications with Indirect Prompt Injection* In arXiv preprint arXiv:2302.12173, 2023.
- T. Gu, B. Dolan-Gavitt, S. Garg, *BadNets: Identifying Vulnerabilities in the Machine Learning Model Supply Chain* In arXiv preprint arXiv:1708.06733, 2017.
- M. Y. Guan, M. Wang, M. Carroll, Z. Dou, A. Y. Wei, M. Williams, B. Arnav, J. Huizinga, I. D. Kivlichan, A. Glaese, J. Pachocki, B. Baker, *Monitoring Monitorability* In Proceedings of the 43rd International Conference on Machine Learning, 2026, pp. 37538–37602.
- I. Gulrajani, D. Lopez-Paz, *In Search of Lost Domain Generalization* In International Conference on Learning Representations, 2021.
- S. Gunasekar, B. E. Woodworth, S. Bhojanapalli, B. Neyshabur, N. Srebro, *Implicit Regularization in Matrix Factorization* In Advances in Neural Information Processing Systems, 2017.
- C. Guo, T. Goldstein, A. Hannun, L. van der Maaten, *Certified Data Removal from Machine Learning Models* In Proceedings of the 37th International Conference on Machine Learning, 2020, pp. 3832–3842.
- C. Guo, G. Pleiss, Y. Sun, K. Q. Weinberger, *On Calibration of Modern Neural Networks* In Proceedings of the 34th International Conference on Machine Learning, 2017, pp. 1321–1330.
- S. Hanneke, *The Optimal Sample Complexity of PAC Learning* In Journal of Machine Learning Research, 2016, vol. 17, no. 38, pp. 1–15.
- A. Hard, K. Rao, R. Mathews, S. Ramaswamy, F. Beaufays, S. Augenstein, H. Eichner, C. Kiddon, D. Ramage, *Federated Learning for Mobile Keyboard Prediction* In arXiv preprint arXiv:1811.03604, 2018.
- M. Hardt, E. Price, N. Srebro, *Equality of Opportunity in Supervised Learning* In arXiv preprint arXiv:1610.02413, 2016.
- M. Hardt, B. Recht, Y. Singer, *Train Faster, Generalize Better: Stability of Stochastic Gradient Descent* In Proceedings of the 33rd International Conference on Machine Learning, 2016, pp. 1225–1234.

- T. Hastie, R. Tibshirani, J. Friedman, *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*, Springer, 2009, 2nd ed.
- Ú. Hébert-Johnson, M. Kim, O. Reingold, G. Rothblum, *Multicalibration: Calibration for the (Computationally-Identifiable) Masses* In Proceedings of the 35th International Conference on Machine Learning, 2018, pp. 1939–1948.
- D. Hendrycks, T. Dietterich, *Benchmarking Neural Network Robustness to Common Corruptions and Perturbations* In International Conference on Learning Representations, 2019.
- D. Hendrycks, K. Gimpel, *A Baseline for Detecting Misclassified and Out-of-Distribution Examples in Neural Networks* In International Conference on Learning Representations, 2017.
- D. Hendrycks, M. Mazeika, T. Dietterich, *Deep Anomaly Detection with Outlier Exposure* In International Conference on Learning Representations, 2019.
- D. Hendrycks, N. Mu, E. D. Cubuk, B. Zoph, J. Gilmer, B. Lakshminarayanan, *AugMix: A Simple Data Processing Method to Improve Robustness and Uncertainty* In International Conference on Learning Representations, 2020.
- J. Hoffmann, S. Borgeaud, A. Mensch, et al., *Training Compute-Optimal Large Language Models* In arXiv preprint arXiv:2203.15556, 2022.
- T. M. Hospedales, A. Antoniou, P. Micaelli, A. J. Storkey, *Meta-Learning in Neural Networks: A Survey* In IEEE Transactions on Pattern Analysis and Machine Intelligence, 2022, vol. 44, no. 9, pp. 5149–5169.
- E. Hubinger, C. Denison, J. Mu, M. Lambert, M. Tong, M. MacDiarmid, T. Lanham, D. M. Ziegler, T. Maxwell, N. Cheng, A. Jermyn, A. Askell, A. Radhakrishnan, C. Anil, D. Duvenaud, D. Ganguli, F. Barez, J. Clark, K. Ndousse, K. Sachan, M. Sellitto, M. Sharma, N. DasSarma, R. Grosse, S. Kravec, Y. Bai, Z. Witten, M. Favaro, J. Brauner, H. Karnofsky, P. Christiano, S. R. Bowman, L. Graham, J. Kaplan, S. Mindermann, R. Greenblatt, B. Shlegeris, N. Schiefer, E. Perez, *Sleeper Agents: Training Deceptive LLMs that Persist Through Safety Training* In arXiv preprint arXiv:2401.05566, 2024.
- D. Hume, *An Enquiry Concerning Human Understanding*, 1748.
- C. Huyen, *Designing Machine Learning Systems*, O'Reilly Media, 2022.
- A. Jacot, F. Gabriel, C. Hongler, *Neural Tangent Kernel: Convergence and Generalization in Neural Networks* In Advances in Neural Information Processing Systems, 2018.

- G. James, D. Witten, T. Hastie, R. Tibshirani, *An Introduction to Statistical Learning*, Springer, 2021, 2nd ed.
- T. Joachims, *Transductive Inference for Text Classification using Support Vector Machines* In Proceedings of the 16th International Conference on Machine Learning, 1999, pp. 200–209.
- T. Joachims, A. Swaminathan, T. Schnabel, *Unbiased Learning-to-Rank with Biased Feedback*, 2016, arXiv: 1608.04468, URL: <https://arxiv.org/abs/1608.04468>.
- D. Jurafsky, J. H. Martin, *Speech and Language Processing*, Prentice Hall, 2009, 2nd ed.
- J. Kaplan, S. McCandlish, T. Henighan, T. B. Brown, B. Chess, R. Child, S. Gray, A. Radford, J. Wu, D. Amodei, *Scaling Laws for Neural Language Models* In arXiv preprint arXiv:2001.08361, 2020.
- A.-H. Karimi, B. Schölkopf, I. Valera, *Algorithmic Recourse: from Counterfactual Explanations to Interventions* In Proceedings of the 2021 ACM Conference on Fairness, Accountability, and Transparency, 2021.
- H. Karimi, J. Nutini, M. Schmidt, *Linear Convergence of Gradient and Proximal-Gradient Methods Under the Polyak–Łojasiewicz Condition* In arXiv preprint arXiv:1608.04636, 2016.
- G. Katz, C. Barrett, D. L. Dill, K. Julian, M. J. Kochenderfer, *Reluplex: An Efficient SMT Solver for Verifying Deep Neural Networks* In arXiv preprint arXiv:1702.01135, 2017.
- M. Kearns, S. Neel, A. Roth, Z. S. Wu, *Preventing Fairness Gerrymandering: Auditing and Learning for Subgroup Fairness* In Proceedings of the 35th International Conference on Machine Learning, 2018, pp. 2564–2572.
- A. Kendall, Y. Gal, R. Cipolla, *Multi-Task Learning Using Uncertainty to Weigh Losses for Scene Geometry and Semantics* In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2018, pp. 7482–7491.
- P. Khosla, P. Teterwak, C. Wang, A. Sarna, Y. Tian, P. Isola, A. Maschinot, C. Liu, D. Krishnan, *Supervised Contrastive Learning* In Advances in Neural Information Processing Systems 33, 2020, pp. 18661–18673.
- B. Kim, M. Wattenberg, J. Gilmer, C. Cai, J. Wexler, F. Viegas, R. Sayres, *Interpretability Beyond Feature Attribution: Quantitative Testing with Concept Activation Vectors (TCAV)* In Proceedings of the 35th International Conference on Machine Learning, 2018, pp. 2668–2677.
- J. Kirkpatrick, R. Pascanu, N. Rabinowitz, J. Veness, G. Desjardins, A. A. Rusu, K. Milan, J. Quan, T. Ramalho, A. Grabska-Barwinska, D. Hassabis, C. Clopath, D. Kumaran, R. Hadsell, *Overcoming Catastrophic For-*

- getting in Neural Networks* In Proceedings of the National Academy of Sciences, 2017.
- J. Kleinberg, S. Mullainathan, M. Raghavan, *Inherent Trade-Offs in the Fair Determination of Risk Scores* In arXiv preprint arXiv:1609.05807, 2016.
- M. Kleppmann, C. Riccomini, *Designing Data-Intensive Applications*, O'Reilly Media, 2026, 2nd ed.
- P. W. Koh, P. Liang, *Understanding Black-box Predictions via Influence Functions* In Proceedings of the 34th International Conference on Machine Learning, 2017, pp. 1885–1894.
- P. W. Koh, T. Nguyen, Y. S. Tang, S. Mussmann, E. Pierson, B. Kim, P. Liang, *Concept Bottleneck Models* In Proceedings of the 37th International Conference on Machine Learning, 2020, pp. 5338–5348.
- P. W. Koh, S. Sagawa, H. Marklund, S. M. Xie, M. Zhang, A. Balsubramani, W. Hu, M. Yasunaga, R. L. Phillips, I. Gao, T. Lee, E. David, I. Stavness, W. Guo, B. Earnshaw, I. Haque, S. M. Beery, J. Leskovec, A. Kundaje, E. Pierson, S. Levine, C. Finn, P. Liang, *WILDS: A Benchmark of in-the-Wild Distribution Shifts* In Proceedings of the 38th International Conference on Machine Learning, 2021, pp. 5637–5664.
- D. Koller, N. Friedman, *Probabilistic Graphical Models: Principles and Techniques*, MIT Press, 2009.
- J. Kossen, J. Han, M. Razzak, L. Schut, S. Malik, Y. Gal, *Semantic Entropy Probes: Robust and Cheap Hallucination Detection in LLMs* In arXiv preprint arXiv:2406.15927, 2024.
- L. Kuhn, Y. Gal, S. Farquhar, *Semantic Uncertainty: Linguistic Invariances for Uncertainty Estimation in Natural Language Generation* In International Conference on Learning Representations, 2023.
- T. Kumar, B. Bordelon, S. J. Gershman, C. Pehlevan, *Grokking as the Transition from Lazy to Rich Training Dynamics* In International Conference on Learning Representations, 2024.
- M. J. Kusner, J. R. Loftus, C. Russell, R. Silva, *Counterfactual Fairness* In Advances in Neural Information Processing Systems, 2017.
- H. Lakkaraju, J. Kleinberg, J. Leskovec, J. Ludwig, S. Mullainathan, *The Selective Labels Problem: Evaluating Algorithmic Predictions in the Presence of Unobservables* In Proceedings of the 23rd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 2017, pp. 275–284.
- B. Lakshminarayanan, A. Pritzel, C. Blundell, *Simple and Scalable Predictive Uncertainty Estimation using Deep Ensembles* In Advances in Neural Information Processing Systems, 2017.

- Y. LeCun, Y. Bengio, G. Hinton, *Deep Learning* In *Nature*, 2015, vol. 521, pp. 436–444.
- Y. LeCun, L. Bottou, Y. Bengio, P. Haffner, *Gradient-Based Learning Applied to Document Recognition* In *Proceedings of the IEEE*, 1998, vol. 86, no. 11, pp. 2278–2324.
- G. J. Lee, J. Pradeepkumar, J. Sun, *Test-Time Adaptation for EEG Foundation Models: A Systematic Study under Real-World Distribution Shifts* In *Proceedings of the 11th Machine Learning for Healthcare Conference*, 2026, pp. 948–984.
- Y. Lei, Y. Ying, *Fine-Grained Analysis of Stability and Generalization for Stochastic Gradient Descent* In *Proceedings of the 37th International Conference on Machine Learning*, 2020, pp. 5809–5819.
- N. Levi, A. Beck, Y. Bar-Sinai, *Grokking in Linear Estimators—A Solvable Model that Groks without Understanding* In *International Conference on Learning Representations*, 2024.
- S. Levine, A. Kumar, G. Tucker, J. Fu, *Offline Reinforcement Learning: Tutorial, Review, and Perspectives on Open Problems* In *arXiv preprint arXiv:2005.01643*, 2020.
- H. Li, R. Wen, S. Shi, N. Zhang, Y. Vorobeychik, C. Xiao, *AgentDyn: Are Your Agent Security Defenses Deployable in Real-World Dynamic Environments?* In *arXiv preprint arXiv:2602.03117*, 2026.
- K. Li, O. Patel, F. Viégas, H. Pfister, M. Wattenberg, *Inference-Time Intervention: Eliciting Truthful Answers from a Language Model* In *arXiv preprint arXiv:2306.03341*, 2023.
- L. Li, W. Chu, J. Langford, R. E. Schapire, *A Contextual-Bandit Approach to Personalized News Article Recommendation* In *Proceedings of the 19th International Conference on World Wide Web*, 2010.
- H. Lightman, V. Kosaraju, Y. Burda, H. Edwards, B. Baker, T. Lee, J. Leike, J. Schulman, I. Sutskever, K. Cobbe, *Let’s Verify Step by Step* In *arXiv preprint arXiv:2305.20050*, 2023.
- K. Liu, B. Dolan-Gavitt, S. Garg, *Fine-Pruning: Defending Against Backdoor-ing Attacks on Deep Neural Networks* In *arXiv preprint arXiv:1805.12185*, 2018.
- L. T. Liu, S. Dean, E. Rolf, M. Simchowitz, M. Hardt, *Delayed Impact of Fair Machine Learning* In *Proceedings of the 35th International Conference on Machine Learning*, 2018, pp. 3150–3158.
- W. Liu, X. Wang, J. D. Owens, Y. Li, *Energy-based Out-of-distribution Detection* In *arXiv preprint arXiv:2010.03759*, 2020.

- G. Loaiza-Ganem, K. Zhang, W. Cui, M. T. Law, K. K. Leung, *Conf-Gen: Conformal Uncertainty Quantification for Generative Models* In Proceedings of the 43rd International Conference on Machine Learning, 2026, pp. 80383–80412.
- Y. Lou, R. Caruana, J. Gehrke, G. Hooker, *Accurate Intelligible Models with Pairwise Interactions* In Proceedings of the 19th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 2013.
- S. Lundberg, S.-I. Lee, *A Unified Approach to Interpreting Model Predictions* In arXiv preprint arXiv:1705.07874, 2017.
- A. Madry, A. Makelov, L. Schmidt, D. Tsipras, A. Vladu, *Towards Deep Learning Models Resistant to Adversarial Attacks* In International Conference on Learning Representations, 2018.
- C. D. Manning, P. Raghavan, H. Schütze, *Introduction to Information Retrieval*, Cambridge University Press, 2008.
- Y. Mansour, M. Mohri, A. Rostamizadeh, *Domain Adaptation: Learning Bounds and Algorithms* In Proceedings of the 22nd Annual Conference on Learning Theory, 2009.
- A. Maurer, *A Note on the PAC Bayesian Theorem*, 2004, arXiv: [cs/0411099](https://arxiv.org/abs/cs/0411099).
- A. Maurer, M. Pontil, B. Romera-Paredes, *The Benefit of Multitask Representation Learning* In Journal of Machine Learning Research, 2016, vol. 17, no. 81, pp. 1–32.
- P. Mayilvahanan, R. S. Zimmermann, T. Wiedemer, E. Rusak, A. Juhos, M. Bethge, W. Brendel, *In Search of Forgotten Domain Generalization* In Proceedings on “I Can’t Believe It’s Not Better: Challenges in Applied Deep Learning” at ICLR 2025 Workshops, 2025, pp. 90–130.
- W. S. McCulloch, W. Pitts, *A Logical Calculus of the Ideas Immanent in Nervous Activity* In The Bulletin of Mathematical Biophysics, 1943, vol. 5, pp. 115–133.
- H. B. McMahan, G. Holt, D. Sculley, M. Young, D. Ebner, J. Grady, L. Nie, T. Phillips, E. Davydov, D. Golovin, S. Chikkerur, D. Liu, M. Wattenberg, A. M. Hrafnkelsson, T. Boulos, J. Kubica, *Ad Click Prediction: A View from the Trenches* In Proceedings of the 19th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 2013, pp. 1222–1230.
- H. B. McMahan, E. Moore, D. Ramage, S. Hampson, B. Agüera y Arcas, *Communication-Efficient Learning of Deep Networks from Decentralized Data* In Proceedings of the 20th International Conference on Artificial Intelligence and Statistics, 2017, pp. 1273–1282.

- S. Mei, T. Misiakiewicz, A. Montanari, *Mean-field Theory of Two-layers Neural Networks: Dimension-free Bounds and Kernel Limit* In arXiv preprint arXiv:1902.06015, 2019.
- S. Mei, A. Montanari, P.-M. Nguyen, *A Mean Field View of the Landscape of Two-Layers Neural Networks* In arXiv preprint arXiv:1804.06561, 2018.
- K. Meng, D. Bau, A. Andonian, Y. Belinkov, *Locating and Editing Factual Associations in GPT* In Advances in Neural Information Processing Systems, 2022.
- E. J. Michaud, Z. Liu, U. Girit, M. Tegmark, *The Quantization Model of Neural Scaling* In Advances in Neural Information Processing Systems, 2023.
- I. Mironov, *Rényi Differential Privacy* In 2017 IEEE 30th Computer Security Foundations Symposium, 2017.
- M. Mitchell, S. Wu, A. Zaldivar, P. Barnes, L. Vasserman, B. Hutchinson, E. Spitzer, I. D. Raji, T. Gebru, *Model Cards for Model Reporting* In Proceedings of the Conference on Fairness, Accountability, and Transparency, 2019.
- T. M. Mitchell, *Machine Learning*, McGraw-Hill, 1997, 1st ed.
- V. Mnih, K. Kavukcuoglu, D. Silver, A. A. Rusu, J. Veness, M. G. Bellemare, A. Graves, M. Riedmiller, A. K. Fidjeland, G. Ostrovski, S. Petersen, C. Beattie, A. Sadik, I. Antonoglou, H. King, D. Kumaran, D. Wierstra, S. Legg, D. Hassabis, *Human-Level Control through Deep Reinforcement Learning* In Nature, 2015, vol. 518, pp. 529–533.
- M. Mohri, A. Rostamizadeh, A. Talwalkar, *Foundations of Machine Learning*, The MIT Press, 2018, 2nd ed.
- S. Moran, A. Yehudayoff, *Sample Compression Schemes for VC Classes* In Journal of the ACM, 2016, vol. 63, no. 3, pp. 21:1–21:10.
- K. Muandet, D. Balduzzi, B. Schölkopf, *Domain Generalization via Invariant Feature Representation* In Proceedings of the 30th International Conference on Machine Learning, 2013, pp. 10–18.
- K. P. Murphy, *Machine Learning: A Probabilistic Perspective*, MIT Press, 2012.
- K. P. Murphy, *Probabilistic Machine Learning*, The MIT Press, 2023.
- K. P. Murphy, *Probabilistic Machine Learning: An Introduction*, MIT Press, 2022.
- N. Nanda, L. Chan, T. Lieberum, J. Smith, J. Steinhardt, *Progress Measures for Grokking via Mechanistic Interpretability* In International Conference on Learning Representations, 2023.
- National Institute of Standards and Technology, *Artificial Intelligence Risk Management Framework (AI RMF 1.0)*, tech. rep. NIST AI 100-1, National Institute of Standards and Technology, 2023.

- A. Y. Ng, M. I. Jordan, *On Discriminative vs. Generative Classifiers: A Comparison of Logistic Regression and Naive Bayes* In Advances in Neural Information Processing Systems 14, 2001, pp. 841–848.
- A. Y. Ng, S. Russell, *Algorithms for Inverse Reinforcement Learning* In Proceedings of the 17th International Conference on Machine Learning, 2000.
- L. Oakden-Rayner, J. Dunnmon, G. Carneiro, C. Ré, *Hidden Stratification Causes Clinically Meaningful Failures in Machine Learning for Medical Imaging* In arXiv preprint arXiv:1909.12475, 2019.
- L. Ouyang, J. Wu, X. Jiang, D. Almeida, C. L. Wainwright, P. Mishkin, C. Zhang, S. Agarwal, K. Slama, A. Ray, J. Schulman, J. Hilton, F. Kelton, L. Miller, M. Simens, A. Askell, P. Welinder, P. Christiano, J. Leike, R. Lowe, *Training Language Models to Follow Instructions with Human Feedback* In arXiv preprint arXiv:2203.02155, 2022.
- Y. Ovadia, E. Fertig, J. Ren, Z. Nado, D. Sculley, S. Nowozin, J. V. Dillon, B. Lakshminarayanan, J. Snoek, *Can You Trust Your Model’s Uncertainty? Evaluating Predictive Uncertainty Under Dataset Shift* In Advances in Neural Information Processing Systems, 2019.
- N. Papernot, M. Abadi, Ú. Erlingsson, I. Goodfellow, K. Talwar, *Semi-supervised Knowledge Transfer for Deep Learning from Private Training Data* In International Conference on Learning Representations, 2017.
- N. Papernot, S. Song, I. Mironov, A. Raghunathan, K. Talwar, Ú. Erlingsson, *Scalable Private Learning with PATE* In International Conference on Learning Representations, 2018.
- A. Parrish, A. Chen, N. Nangia, V. Padmakumar, J. Phang, J. Thompson, P. M. Htut, S. R. Bowman, *BBQ: A Hand-Built Bias Benchmark for Question Answering* In Findings of the Association for Computational Linguistics: ACL 2022, 2022, pp. 2086–2105.
- A. Power, Y. Burda, H. Edwards, I. Babuschkin, V. Misra, *Grokking: Generalization Beyond Overfitting on Small Algorithmic Datasets* In arXiv preprint arXiv:2201.02177, 2022.
- G. Pruthi, F. Liu, S. Kale, M. Sundararajan, *Estimating Training Data Influence by Tracing Gradient Descent* In Advances in Neural Information Processing Systems, 2020.
- A. Radford, J. W. Kim, C. Hallacy, A. Ramesh, G. Goh, S. Agarwal, G. Sastry, A. Askell, P. Mishkin, J. Clark, G. Krueger, I. Sutskever, *Learning Transferable Visual Models from Natural Language Supervision* In Proceedings of the 38th International Conference on Machine Learning, 2021, pp. 8748–8763.

- R. Rafailov, A. Sharma, E. Mitchell, S. Ermon, C. D. Manning, C. Finn, *Direct Preference Optimization: Your Language Model is Secretly a Reward Model* In arXiv preprint arXiv:2305.18290, 2023.
- C. E. Rasmussen, C. K. I. Williams, *Gaussian Processes for Machine Learning*, MIT Press, 2006.
- A. Ratner, S. H. Bach, H. Ehrenberg, J. Fries, S. Wu, C. Ré, *Snorkel: Rapid Training Data Creation with Weak Supervision* In Proceedings of the VLDB Endowment, 2017, vol. 11, no. 3, pp. 269–282.
- N. Razin, N. Cohen, *Implicit Regularization in Deep Learning May Not Be Explainable by Norms* In Advances in Neural Information Processing Systems, 2020.
- S.-A. Rebuffi, A. Kolesnikov, G. Sperl, C. H. Lampert, *iCaRL: Incremental Classifier and Representation Learning* In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2017, pp. 5533–5542.
- H. Reisizadeh, J. Ruan, Y. Chen, S. Pal, S. Liu, M. Hong, *Leak@k: Unlearning Does Not Make LLMs Forget Under Probabilistic Decoding* In Proceedings of the 43rd International Conference on Machine Learning, 2026, pp. 104291–104315.
- M. T. Ribeiro, S. Singh, C. Guestrin, *“Why Should I Trust You?”: Explaining the Predictions of Any Classifier* In arXiv preprint arXiv:1602.04938, 2016.
- M. T. Ribeiro, T. Wu, C. Guestrin, S. Singh, *Beyond Accuracy: Behavioral Testing of NLP Models with CheckList* In Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics, 2020, pp. 4902–4912.
- Y. Romano, E. Patterson, E. J. Candès, *Conformalized Quantile Regression* In arXiv preprint arXiv:1905.03222, 2019.
- Y. Romano, M. Sesia, E. Candès, *Classification with Valid and Adaptive Coverage* In Advances in Neural Information Processing Systems, 2020.
- F. Rosenblatt, *The Perceptron: A Probabilistic Model for Information Storage and Organization in the Brain* In Psychological Review, 1958, vol. 65, no. 6, pp. 386–408.
- E. Rosenfeld, P. Ravikumar, A. Risteski, *The Risks of Invariant Risk Minimization* In International Conference on Learning Representations, 2021.
- S. Ross, G. Gordon, D. Bagnell, *A Reduction of Imitation Learning and Structured Prediction to No-Regret Online Learning* In Proceedings of the Fourteenth International Conference on Artificial Intelligence and Statistics, 2011, pp. 627–635.

- D. E. Rumelhart, G. E. Hinton, R. J. Williams, *Learning representations by back-propagating errors* In *Nature*, 1986, vol. 323, no. 6088, pp. 533–536.
- D. Russo, J. Zou, *Controlling Bias in Adaptive Data Analysis Using Information Theory* In *Proceedings of the 19th International Conference on Artificial Intelligence and Statistics*, 2016, pp. 1232–1240.
- S. Sagawa, P. W. Koh, T. B. Hashimoto, P. Liang, *Distributionally Robust Neural Networks for Group Shifts: On the Importance of Regularization for Worst-Case Generalization* In *International Conference on Learning Representations*, 2020.
- A. L. Samuel, *Some Studies in Machine Learning Using the Game of Checkers* In *IBM Journal of Research and Development*, 1959, vol. 3, no. 3, pp. 210–229.
- R. Schaeffer, B. Miranda, S. Koyejo, *Are Emergent Abilities of Large Language Models a Mirage?* In *Advances in Neural Information Processing Systems* 36, 2023.
- R. R. Selvaraju, M. Cogswell, A. Das, R. Vedantam, D. Parikh, D. Batra, *Grad-CAM: Visual Explanations from Deep Networks via Gradient-based Localization* In *Proceedings of the IEEE International Conference on Computer Vision*, 2017.
- A. Shafahi, W. R. Huang, M. Najibi, O. Suci, C. Studer, T. Dumitras, T. Goldstein, *Poison Frogs! Targeted Clean-Label Poisoning Attacks on Neural Networks* In *arXiv preprint arXiv:1804.00792*, 2018.
- S. Shalev-Shwartz, S. Ben-David, *Understanding Machine Learning: From Theory to Algorithms*, Cambridge University Press, 2014, 1st ed.
- S. Shalev-Shwartz, O. Shamir, N. Srebro, K. Sridharan, *Learnability, Stability and Uniform Convergence* In *Journal of Machine Learning Research*, 2010, vol. 11, no. 90, pp. 2635–2670.
- R. Shokri, M. Stronati, C. Song, V. Shmatikov, *Membership Inference Attacks against Machine Learning Models* In *2017 IEEE Symposium on Security and Privacy*, 2017.
- D. Silver, A. Huang, C. J. Maddison, A. Guez, L. Sifre, G. van den Driessche, J. Schrittwieser, I. Antonoglou, V. Panneershelvam, M. Lanctot, S. Dieleman, D. Grewe, J. Nham, N. Kalchbrenner, I. Sutskever, T. Lillicrap, M. Leach, K. Kavukcuoglu, T. Graepel, D. Hassabis, *Mastering the Game of Go with Deep Neural Networks and Tree Search* In *Nature*, 2016, vol. 529, pp. 484–489.
- A. J. Smola, T.-T. Frieß, B. Schölkopf, *Semiparametric Support Vector and Linear Programming Machines* In *Advances in Neural Information Processing Systems* 11, 1998.

- K. Sohn, D. Berthelot, C.-L. Li, Z. Zhang, N. Carlini, E. D. Cubuk, A. Kurakin, H. Zhang, C. Raffel, *FixMatch: Simplifying Semi-Supervised Learning with Consistency and Confidence* In Advances in Neural Information Processing Systems 33, 2020, pp. 596–608.
- X. Song, A. Muhamed, Y. Zheng, L. Kong, Z. Tang, M. T. Diab, V. Smith, K. Zhang, *Mechanistic Interpretability Should Prioritize Feature Consistency in Sparse Autoencoders* In Proceedings of the 64th Annual Meeting of the Association for Computational Linguistics, 2026, pp. 2172–2210.
- D. Soudry, E. Hoffer, M. S. Nacson, S. Gunasekar, N. Srebro, *The Implicit Bias of Gradient Descent on Separable Data* In Journal of Machine Learning Research, 2018, vol. 19, no. 70, pp. 1–57.
- T. Steinke, L. Zakynthinou, *Reasoning About Generalization via Conditional Mutual Information* In Proceedings of the Thirty Third Conference on Learning Theory, 2020, pp. 3437–3452.
- M. Sundararajan, A. Taly, Q. Yan, *Axiomatic Attribution for Deep Networks* In Proceedings of the 34th International Conference on Machine Learning, 2017, pp. 3319–3328.
- R. S. Sutton, A. G. Barto, *Reinforcement Learning: An Introduction*, MIT Press, 2018, 2nd ed.
- C. Szegedy, W. Zaremba, I. Sutskever, J. Bruna, D. Erhan, I. Goodfellow, R. Fergus, *Intriguing Properties of Neural Networks* In arXiv preprint arXiv:1312.6199, 2014.
- R. Szeliski, *Computer Vision*, Springer, 2022, 2nd ed.
- C. Szepesvári, *Algorithms for Reinforcement Learning*, Morgan & Claypool Publishers, 2010.
- M. Terekhov, A. Panfilov, D. Dzenhaliou, C. Gulcehre, M. Andriushchenko, A. Prabhu, J. Geiping, *Adaptive Attacks on Trusted Monitors Subvert AI Control Protocols* In International Conference on Learning Representations, 2026.
- R. Thareja, P. Nakov, P. Vepakomma, N. Lukas, *DP-Fusion: Token-Level Differentially Private Inference for Large Language Models* In International Conference on Learning Representations, 2026.
- M. E. Tipping, C. M. Bishop, *Probabilistic Principal Component Analysis* In Journal of the Royal Statistical Society: Series B (Statistical Methodology), 1999, vol. 61, no. 3, pp. 611–622.
- F. Tramèr, F. Zhang, A. Juels, M. K. Reiter, T. Ristenpart, *Stealing Machine Learning Models via Prediction APIs* In arXiv preprint arXiv:1609.02943, 2016.

- B. Tran, J. Li, A. Madry, *Spectral Signatures in Backdoor Attacks* In Advances in Neural Information Processing Systems, 2018.
- A. M. Turing, *Computing Machinery and Intelligence* In Mind, 1950, vol. 59, no. 236, pp. 433–460.
- B. Ustun, A. Spangher, Y. Liu, *Actionable Recourse in Linear Classification* In Proceedings of the Conference on Fairness, Accountability, and Transparency, 2019.
- L. G. Valiant, *A Theory of the Learnable* In Communications of the ACM, 1984, vol. 27, no. 11, pp. 1134–1142.
- V. N. Vapnik, A. Y. Chervonenkis, *On the Uniform Convergence of Relative Frequencies of Events to Their Probabilities* In Theory of Probability and Its Applications, 1971, vol. 16, no. 2, pp. 264–280.
- G. M. van de Ven, A. S. Tolas, *Three Scenarios for Continual Learning* In arXiv preprint arXiv:1904.07734, 2019.
- S. Wachter, B. Mittelstadt, C. Russell, *Counterfactual Explanations without Opening the Black Box: Automated Decisions and the GDPR* In Harvard Journal of Law & Technology, 2018.
- B. Wang, X. Qiao, *Conformal Prediction Under Generalized Covariate Shift with Posterior Drift* In Proceedings of the 28th International Conference on Artificial Intelligence and Statistics, 2025, pp. 4888–4896.
- B. Wang, Y. Yao, S. Shan, H. Li, B. Viswanath, H. Zheng, B. Y. Zhao, *Neural Cleanse: Identifying and Mitigating Backdoor Attacks in Neural Networks* In 2019 IEEE Symposium on Security and Privacy, 2019, pp. 707–723.
- D. Wang, E. Shelhamer, S. Liu, B. Olshausen, T. Darrell, *Tent: Fully Test-Time Adaptation by Entropy Minimization* In International Conference on Learning Representations, 2021.
- Y. Wang, Q. Yao, J. T. Kwok, L. M. Ni, *Generalizing from a Few Examples: A Survey on Few-Shot Learning* In ACM Computing Surveys, 2020, vol. 53, no. 3, pp. 1–34.
- J. H. Ward Jr., *Hierarchical Grouping to Optimize an Objective Function* In Journal of the American Statistical Association, 1963, vol. 58, no. 301, pp. 236–244.
- K. Q. Weinberger, L. K. Saul, *Distance Metric Learning for Large Margin Nearest Neighbor Classification* In Journal of Machine Learning Research, 2009, vol. 10, no. 9, pp. 207–244.
- A. Xu, M. Raginsky, *Information-Theoretic Analysis of Generalization Capability of Learning Algorithms* In Advances in Neural Information Processing Systems, 2017.

- D. Yin, Y. Chen, K. Ramchandran, P. Bartlett, *Byzantine-Robust Distributed Learning: Towards Optimal Statistical Rates* In Proceedings of the 35th International Conference on Machine Learning, 2018, pp. 5650–5659.
- J. Yosinski, J. Clune, Y. Bengio, H. Lipson, *How Transferable Are Features in Deep Neural Networks?* In Advances in Neural Information Processing Systems 27, 2014, pp. 3320–3328.
- R. Zemel, Y. Wu, K. Swersky, T. Pitassi, C. Dwork, *Learning Fair Representations* In Proceedings of the 30th International Conference on Machine Learning, 2013, pp. 325–333.
- A. Zhang, Z. C. Lipton, M. Li, A. J. Smola, *Dive into Deep Learning*, Cambridge University Press, 2023.
- B. H. Zhang, B. Lemoine, M. Mitchell, *Mitigating Unwanted Biases with Adversarial Learning* In arXiv preprint arXiv:1801.07593, 2018.
- C. Zhang, S. Bengio, M. Hardt, B. Recht, O. Vinyals, *Understanding Deep Learning (Still) Requires Rethinking Generalization* In Communications of the ACM, 2021, vol. 64, no. 3, pp. 107–115.
- H. Zhang, Y. Yu, J. Jiao, E. P. Xing, L. El Ghaoui, M. I. Jordan, *Theoretically Principled Trade-off between Robustness and Accuracy* In Proceedings of the 36th International Conference on Machine Learning, 2019, pp. 7472–7482.
- H. Zhang, M. Cisse, Y. N. Dauphin, D. Lopez-Paz, *mixup: Beyond Empirical Risk Minimization* In International Conference on Learning Representations, 2018.
- R. Zhang, L. Lin, Y. Bai, S. Mei, *Negative Preference Optimization: From Catastrophic Collapse to Effective Unlearning* In arXiv preprint arXiv:2404.05868, 2024.
- Z. Zhou, M. Yang, S.-Y. Tian, K.-Y. Yu, L.-Z. Guo, Y.-F. Li, *On the Learnability of Test-Time Adaptation: A Recovery Complexity Perspective* In arXiv preprint arXiv:2605.28057, 2026.
- Z.-H. Zhou, *A Brief Introduction to Weakly Supervised Learning* In National Science Review, 2018, vol. 5, no. 1, pp. 44–53.
- L. Zhu, Z. Liu, S. Han, *Deep Leakage from Gradients* In Advances in Neural Information Processing Systems, 2019.
- X. Zhu, Z. Ghahramani, J. Lafferty, *Semi-Supervised Learning Using Gaussian Fields and Harmonic Functions* In Proceedings of the Twentieth International Conference on Machine Learning, 2003, pp. 912–919.
- A. Zou, Z. Wang, N. Carlini, M. Nasr, J. Z. Kolter, M. Fredrikson, *Universal and Transferable Adversarial Attacks on Aligned Language Models* In arXiv preprint arXiv:2307.15043, 2023.

周志华, 机器学习, 清华大学出版社, 2016, 1st ed.

李航, 统计学习方法, 清华大学出版社, 2019, 2nd ed.

邱锡鹏, 神经网络与深度学习, 机械工业出版社, 2020.

索引

- 一致, consistent, 116
- 一致性约束, consistency regularization, 62
- 一致收敛, uniform convergence, 119
- 三元组损失, triplet loss, 47
- 上下文学习, in-context learning, 79
- 上下文老虎机问题, contextual bandit, 60
- 下游任务, downstream task, 65
- 不可知 PAC 可学习的, agnostic PAC learnable, 98
- 不可知设定, agnostic setting, 98
- 个体公平, individual fairness, 345
- 主动学习, active learning, 68
- 主成分分析, principal component analysis, 28
- 二分类, binary classification, 5
- 二分类交叉熵, binary cross-entropy, 7
- 二次判别分析, quadratic discriminant analysis, 50
- 互信息, mutual information, 194
- 交叉熵, cross-entropy, 45
- 人口统计均等, demographic parity, 341
- 人工智能, artificial intelligence, 3
- 人类反馈强化学习, reinforcement learning from human feedback, 379
- 代理损失, surrogate loss, 44
- 任务, task, 5
- 任务增量学习, task-incremental learning, 72
- 优化, optimization, 4
- 伪标签, pseudo-label, 62
- 伪立方体, pseudo-cube, 162
- 估计误差, estimation error, 108
- 似然, likelihood, 33
- 似然比攻击, Likelihood Ratio Attack, 421
- 余弦相似度, cosine similarity, 44
- 信息抽取, information extraction, 13
- 信息检索, information retrieval, 16
- 信息泄漏, information leakage, 21
- 灾难性遗忘, catastrophic forgetting, 71
- 点估计, point estimation, 35
- 点击率预测, click-through rate prediction, 16
- 特征, feature, 6
- 状态, state, 58
- 独热表示, one-hot representation, 45
- 独立同分布, independent and identically distributed, 20, 94
- 环境, environment, 58
- 环境平均领域泛化, environment-averaged domain generalization, 258, 264
- 环境模型, environment model, 59
- 生成, generation, 19
- 生成式建模, generative modeling, 32
- 生成式摘要, abstractive summarization, 13
- 生成式问答, generative question answering, 13
- 生长函数, growth function, 124
- 监督学习, supervised learning, 55
- 监督微调, supervised fine-tuning, 378
- 目标域, target domain, 75, 257
- 目标域超额期望风险, target-domain excess expected risk, 258
- 目标对齐, alignment, 361
- 目标检测, object detection, 14
- 直接偏好优化, direct preference optimization, 379
- 直推学习, transductive learning, 63
- 相对熵, relative entropy, 194
- 离线强化学习, offline reinforcement learning, 61
- 积分梯度, integrated gradients, 398
- 稳定秩, stable rank, 224
- 策略, policy, 58
- 算法稳定性, algorithmic stability, 171
- 类别增量学习, class-incremental learning, 71
- 精确率, precision, 22
- 系统辨识, system identification, 17
- 累积局部效应, accumulated local effects, 392
- 细胞类型识别, cell type identification, 17
- 经验, experience, 5

- 经验 Rademacher 复杂度, empirical Rademacher complexity, 129
- 经验优化误差, empirical optimization error, 109
- 经验风险, empirical risk, 8
- 经验风险最小化, empirical risk minimization, 8, 101
- 经验高斯复杂度, empirical Gaussian complexity, 134
- 结构化预测, structured prediction, 13
- 结构风险最小化, structural risk minimization, 111
- 结果监督, outcome supervision, 368
- 统计学, statistics, 4
- 缩放定律, scaling law, 251
- 置信度, confidence, 62
- 联邦学习, federated learning, 81
- 联邦平均, federated averaging, 82
- 聚类, clustering, 19, 56
- 胖打散, fat-shattering, 174
- 胖打散维, fat-shattering dimension, 174
- 能量分数, energy score, 333
- 自然语言处理, natural language processing, 12
- 自然语言推断, natural language inference, 13
- 自监督学习, self-supervised learning, 64
- 自训练, self-training, 62
- 自适应共形推断, adaptive conformal inference, 315
- 蒙特卡洛失活, Monte Carlo dropout, 303
- 行为克隆, behavior cloning, 61
- 行为测试, behavioral testing, 294
- 行为约束, behavioral constraint, 361
- 行动者—评论家, actor-critic, 59
- 表征性伤害, representational harm, 339
- 表示, representation, 6
- 表示学习, representation learning, 3
- 装袋法, bootstrap aggregating, 140
- 观测, observation, 58
- 视图, view, 62
- 认知不确定性, epistemic uncertainty, 301
- 训练, training, 8
- 训练集, training set, 6
- 评分预测, rating prediction, 16
- 词元, token, 64
- 词性标注, part-of-speech tagging, 12
- 语义分割, semantic segmentation, 14, 73
- 语义匹配, semantic matching, 13
- 语义熵, semantic entropy, 318
- 语音合成, speech synthesis, 17
- 语音处理, speech processing, 17
- 语音识别, speech recognition, 17
- 误差反向传播, error backpropagation, 3
- 贝叶斯分类器, Bayes classifier, 107
- 贝叶斯推断, Bayesian inference, 35
- 贝叶斯风险, Bayes risk, 107
- 负样本对, negative pair, 67
- 负类, negative class, 5
- 负迁移, negative transfer, 75
- 责任主体, accountable role, 296
- 超参数, hyperparameter, 8
- 超额期望风险, excess risk, 98, 178
- 越狱, jailbreak, 441
- 转化率预测, conversion rate prediction, 16
- 输入, input, 92
- 输入:, Input:, 9
- 输出:, Output:, 9
- 边界框, bounding box, 14
- 边缘分布, marginal distribution, 108
- 迁移学习, transfer learning, 74, 257
- 过参数化, overparameterization, 215
- 过拟合, overfitting, 11
- 过程监督, process supervision, 368
- 近似误差, approximation error, 108
- 适当评分规则, proper scoring rule, 307
- 逆强化学习, inverse reinforcement learning, 61
- 选择性标签, selective labels, 340
- 选择性预测, selective prediction, 310
- 逐点方法, pointwise approach, 18
- 逐目标域领域泛化, per-target domain generalization, 258, 263
- 逻辑函数, logistic function, 7
- 部分依赖, partial dependence, 391
- 重排序, reranking, 17
- 间隔, margin, 47
- 阈值, threshold, 7, 91
- 降维, dimensionality reduction, 19, 56
- 限制, restriction, 122
- 随机响应, randomized response, 425
- 随机平滑, randomized smoothing, 326
- 随机森林, random forest, 29
- 隐式偏差, implicit bias, 233
- 隐私保护, privacy protection, 415
- 隐藏分层, hidden stratification, 292
- 集成学习, ensemble learning, 53, 139
- 零一损失, zero-one loss, 43, 93
- 零样本学习, zero-shot learning, 77
- 非参数化模型族, nonparametric model family, 28
- 非恰当学习, improper learning, 90

- 非概率模型, non-probabilistic model, 31
- 顿悟, grokking, 253
- 预言机不等式, oracle inequality, 113
- 预训练, pre-training, 65
- 领域增量学习, domain-incremental learning, 72
- 领域泛化, domain generalization, 76, 258
- 领域自适应, domain adaptation, 75, 258
- 风险接受, risk acceptance, 296
- 验证集, validation set, 6, 110
- 高效学习, efficient learning, 91
- 高斯判别分析, Gaussian discriminant analysis, 33
- 高斯混合模型, Gaussian mixture model, 31
- 高斯过程, Gaussian process, 36
- 鲁棒性, robustness, 321

- Brier 评分, Brier score, 45

- DBSCAN, density-based spatial clustering of applications with noise, 52
- DS 打散, DS shattering, 162
- DS 维, Daniely-Shalev-Shwartz dimension, 151

- F_1 值, F1 score, 22

- KL 散度, Kullback-Leibler divergence, 45
- K 均值模型, K-means, 27
- k 近邻, k -nearest neighbors, 28

- Natarajan 打散, Natarajan shattering, 153
- Natarajan 维, Natarajan dimension, 153

- PAC 学习, probably approximately correct learning, 95

- Rademacher 复杂度, Rademacher complexity, 128
- Rényi 差分隐私, Rényi differential privacy, 430

- Schatten 范数, Schatten norm, 224

- 候选召回, candidate retrieval, 16
- 候选生成, candidate generation, 16
- 假设, hypothesis, 92
- 假设空间, hypothesis space, 7, 92
- 偏好学习, preference learning, 84
- 偏差与复杂度的权衡, bias-complexity trade-off, 109
- 偏置, bias, 7
- 偶然不确定性, aleatoric uncertainty, 301

- 元学习, meta-learning, 77
- 元训练, meta-training, 78
- 先验分布, prior distribution, 35
- 公平性, fairness, 338
- 共形分位数回归, conformalized quantile regression, 313
- 共形预测, conformal prediction, 312
- 关系抽取, relation extraction, 13
- 关键点, keypoint, 15
- 再生核希尔伯特空间, reproducing kernel Hilbert space, 228
- 决策树, decision tree, 29
- 决策补救, recourse, 408
- VC 维, Vapnik-Chervonenkis dimension, 123
- 准确率, accuracy, 22
- 凝聚层次聚类, agglomerative hierarchical clustering, 52
- 凸包, convex hull, 140
- 分位数损失, pinball loss, 304
- 分子性质预测, molecular property prediction, 17
- 分子生成, molecular generation, 17
- 分布变化, distribution shift, 12
- 分布外检测, out-of-distribution detection, 327
- 分布建模, distribution modeling, 56
- 分布鲁棒优化, distributionally robust optimization, 331
- 分类, classification, 18
- 分类校准, classification calibration, 201
- 分配性伤害, allocative harm, 339
- 列表方法, listwise approach, 19
- 判别式建模, discriminative modeling, 32
- 副样本, ghost sample, 126
- 半参数化模型, semiparametric model, 29
- 半监督学习, semi-supervised learning, 62
- 协方差, covariance, 50
- 单次解释, local explanation, 388
- 参数化模型族, parametric model family, 27
- 参数稳定性, argument stability, 188
- 双重下降, double descent, 217
- 反事实公平, counterfactual fairness, 346
- 反事实解释, counterfactual explanation, 396
- 召回率, recall, 22
- 可信保证, trustworthiness assurance, 293
- 可信机器学习, trustworthy machine learning, 286
- 可实现的, realizable, 96
- 可扩展监督, scalable oversight, 369
- 可监控性, monitorability, 384
- 可解释性, interpretability, 387
- 可计算 Natarajan 维, computable Natarajan dimension, 167
- 可计算 PAC 可学习的, computably PAC learnable, 146

- 可计算学习, computable learning, 91
- 可识别性, identifiability, 261
- 可靠性, reliability, 300
- 合页损失, hinge loss, 47
- 后门, backdoor, 441
- 后验分布, posterior distribution, 35
- 向量输出, vector output, 41
- 命名实体识别, named entity recognition, 12
- 回归, regression, 13
- 图像分割, image segmentation, 14
- 图像分类, image classification, 13
- 图像处理, image processing, 13
- 图像生成, image generation, 15
- 图像重建, image reconstruction, 15
- 图打散, graph shattering, 159
- 图维, graph dimension, 151
- 在线学习, online learning, 81
- 均方误差, mean squared error, 23
- 均等化赔率, equalized odds, 342
- 垃圾信息检测, spam detection, 12
- 域, domain, 75
- 基于图的方法, graph-based methods, 62
- 基于案例的解释, example-based explanation, 395
- 基线, baseline, 5
- 多任务学习, multi-task learning, 73
- 多分类, multiclass classification, 18
- 多标签分类, multilabel classification, 18
- 多示例学习, multiple-instance learning, 66
- 多臂老虎机问题, multi-armed bandit, 60
- 多重校准, multicalibration, 345
- 失效触发, invalidation trigger, 296
- 奖励, reward, 58
- 奖励投机, reward hacking, 362
- 姿态估计, pose estimation, 15
- 威胁模型, threat model, 442
- 子群公平, subgroup fairness, 341
- 学习排序, learning to rank, 16
- 学习率, learning rate, 8
- 学习算法, learning algorithm, 10, 94
- 学习范式, learning paradigm, 19
- 安全屏蔽, shielding, 373
- 实例分割, instance segmentation, 14, 73
- 宪法式人工智能, Constitutional AI, 367
- 容量, capacity, 27
- 对抗去偏, adversarial debiasing, 353
- 对抗安全, adversarial security, 440
- 对抗攻击, adversarial attack, 440
- 对抗样本, adversarial example, 441
- 对数几率, log-odds, 37
- 对比学习, contrastive learning, 67
- 对称化, symmetrization, 126
- 少样本学习, few-shot learning, 77
- 局部可解释模型无关解释, local interpretable model-agnostic explanations, 397
- 差分隐私, differential privacy, 417
- 差分隐私随机梯度下降, differentially private stochastic gradient descent, 425
- 干净标签投毒, clean-label poisoning, 450
- 平均场理论, mean-field theory, 243
- 平均稳定性, on-average stability, 186
- 平均绝对误差, mean absolute error, 22
- 广义加性模型, generalized additive model, 390
- 序列推荐, sequential recommendation, 17
- 序列标注, sequence labeling, 12
- 序列预测, sequence prediction, 18
- 序贯决策, sequential decision making, 17
- 应用场景, application scenario, 18
- 度量学习, metric learning, 47
- 异常暴露, outlier exposure, 333
- 异常检测, anomaly detection, 4
- 弱到强化化, weak-to-strong generalization, 370
- 弱学习, weak learning, 97
- 弱监督学习, weakly supervised learning, 65
- 强化学习, reinforcement learning, 58
- 强学习, strong learning, 97
- 归纳, induction, 2
- 归纳偏置, inductive bias, 7, 92
- 归纳学习, inductive learning, 63
- 微调, fine-tuning, 75
- 忠实性, fidelity, 403
- 快速梯度符号法, fast gradient sign method, 447
- 性能度量, performance measure, 5
- Ward 方法, Ward method, 52
- 恰当学习, proper learning, 90
- 情感分析, sentiment analysis, 12
- 惰性训练, lazy training, 227
- 意图识别, intent recognition, 12
- 感知机, perceptron, 3, 37
- 成员推断, membership inference, 416
- 成对方法, pairwise approach, 18
- 成本敏感分类, cost-sensitive classification, 354

- 打散, shatter, 122
- 批量学习, batch learning, 81
- 折扣因子, discount factor, 58
- 抽取式摘要, extractive summarization, 13
- 持续学习, continual learning, 71
- 损失, loss, 93
- 损失函数, loss function, 7
- 捷径学习, shortcut learning, 322
- 排序, ranking, 13
- 推理, inference, 10
- 推荐, recommendation, 15
- 提升, boosting, 141
- 提示注入, prompt injection, 441
- 插值, interpolation, 215
- 搜索, search, 15
- 支持向量, support vector, 30
- 支持向量机, support vector machine, 30
- 收缩引理, contraction lemma, 133
- 故障诊断, fault diagnosis, 17
- 教师集成的私有聚合, Private Aggregation of Teacher Ensembles, 426
- 数据分布, data distribution, 20
- 数据投毒, data poisoning, 441
- 数据挖掘, data mining, 4
- 数据集, dataset, 6
- 整体代理, global surrogate, 390
- 整体解释, global explanation, 388
- 文本分类, text classification, 12
- 文本摘要, text summarization, 13
- 文本生成, text generation, 13
- 文本聚类, text clustering, 12
- 旁信息, side information, 136
- 无监督学习, unsupervised learning, 56
- 无监督领域自适应, unsupervised domain adaptation, 76
- 智能体, agent, 58
- 智能问答, question answering, 13
- 最大似然估计, maximum likelihood estimation, 35
- 最大类别概率, maximum softmax probability, 333
- 有效 VC 维, effective VC dimension, 147
- 期望 Rademacher 复杂度, expected Rademacher complexity, 129
- 期望泛化差, expected generalization gap, 178
- 期望风险, expected risk, 23
- 本地差分隐私, local differential privacy, 418
- 朴素贝叶斯, naive Bayes, 33
- 机会均等, equal opportunity, 342
- 机器学习, machine learning, 3
- 机器翻译, machine translation, 13
- 机器遗忘, machine unlearning, 431
- 权重, weight, 7
- 条件作用, conditioning, 2
- 条件生成, conditional generation, 13
- 查询理解, query understanding, 16
- 标注函数, labeling function, 66
- 标签, label, 5, 92
- 标量输出, scalar output, 41
- 校准性, calibration, 306
- 样本, sample, 6
- 样本压缩, sample compression, 136
- 样本压缩猜想, sample compression conjecture, 139
- 样本复杂度, sample complexity, 96
- 核回归, kernel regression, 29
- 核方法, kernel method, 40
- 核范数, nuclear norm, 239
- 梯度下降, gradient descent, 8
- 梯度动力学, gradient dynamics, 233
- 梯度掩蔽, gradient masking, 448
- 概念偏移, concept shift, 259
- 概念漂移, concept drift, 81
- 概念激活向量检验, testing with concept activation vectors, 393
- 概念瓶颈模型, concept bottleneck model, 393
- 概率主成分分析, probabilistic principal component analysis, 32
- 概率分布输出, probability distribution output, 42
- 概率图模型, probabilistic graphical model, 35
- 概率推断, probabilistic inference, 34
- 概率模型, probabilistic model, 31
- 概率论, probability theory, 4
- 模仿学习, imitation learning, 61
- 模型, model, 7
- 模型参数, model parameters, 7
- 模型族, model family, 25
- 模型无关元学习, model-agnostic meta-learning, 78
- 模糊 C 均值, fuzzy c-means, 51
- 欠拟合, underfitting, 11
- 欠规定性, underspecification, 291
- 正则化, regularization, 11
- 正样本对, positive pair, 67
- 正类, positive class, 5
- 正预测值均等, predictive parity, 343
- 没有免费的午餐, no-free-lunch, 102
- 泛化, generalization, 11

泛化差, generalization gap, 93

测试时适应, test-time adaptation, 76, 334

测试集, test set, 6, 110

深度估计, depth estimation, 73

深度学习, deep learning, 3

深度集成, deep ensembles, 303

混合增强, mixup, 329

混淆矩阵, confusion matrix, 22

源域, source domain, 75, 257

漂移检测, drift detection, 328

演绎, deduction, 2

激活函数, activation function, 40