



MACHINE LEARNING NOTES

机器学习笔记

卷三：模型

施晓罡

2026 年 · 第一版



MACHINE LEARNING NOTES

机器学习笔记

卷三：模型

施晓罡

2026 年 · 第一版

机器学习笔记

MACHINE LEARNING NOTES

作者：施晓罡

版本：第一版

年份：2026

Copyright © 2026 施晓罡



Licensed under the Creative Commons Attribution-NonCommercial-NoDerivatives 4.0 International License (the "License");

You may not use this file except in compliance with the License.

You may obtain a copy of the License at

<https://creativecommons.org/licenses/by-nc-nd/4.0/>

Unless required by applicable law or agreed to in writing, software distributed under the License is distributed on an "AS IS" BASIS, WITHOUT WARRANTIES OR CONDITIONS OF ANY KIND, either express or implied. See the License for the specific language governing permissions and limitations under the License.





前言

本书目标

机器学习把数据、模型和计算连接起来，但理解一种方法，不能只记住模型名称或训练步骤。还需要知道模型能够表示什么规律，学习结论依赖哪些数据与假设，什么证据足以支持评价，以及方法进入具体应用和运行系统后会受到哪些约束。本书沿着这些联系组织内容，希望读者不仅会使用算法，也能解释一个结果为何成立、何时可信，以及怎样把它放入完整的技术过程。

本书面向已经具备基本微积分、线性代数、概率统计和编程基础，希望系统理解机器学习的读者。正文会在需要时回顾具体工具，但不以这些基础课程的完整讲解为目标。阅读后，读者应能从任务和证据出发比较模型与学习方式，并把理论条件、实验评价、应用要求和系统实现放在同一条推理链上考察。

本书内容

全书分为六卷。第一卷“数学准备”建立分析、代数、概率、离散结构与动态决策的共同语言。第二卷“基础、理论和可信性”说明学习如何发生、学习保证依赖哪些条件，以及可靠性、鲁棒性、公平性和隐私等可信要求应由什么证据支持。第三卷“模型”考察经典模型、神经网络模型和概率图模型的结构、推断与学习。第四卷“范式”转向经验和知识的获得方式，讨论交互反馈、有限标注以及任务变化下如何学习、复用和迁移知识。前四卷提供数学工具、分析依据和方法选择，后两卷把这些选择放入实际约束。第五卷“应用”围绕自然语言处理、图像处理、推荐与搜索，说明任务目标、数据形态、模型和评价方式如何相互制约。第六卷“系统”连接数据准备、训练计算、部署服务与运行维护，考察方法如何成为可持续运行的机器学习系统。这样的次序并不表示建模、应用和系统彼此割裂：应用需求决定评价口径，系统条件限制可用方法，而运行中的证据又会促使模型和学习过程重新调整。

参考资料

下面按内容列出可与本书配合阅读的教材。每本书的侧重点不同，读者可以根据正在阅读的卷和需要补充的问题选择查阅，不必按列表顺序通读。

综合与基础

- Mitchell 的 *Machine Learning* 从概念学习、归纳偏置和代表性算法出发，适合查阅机器学习的基本问题和早期统一框架。
- Bishop 的 *Pattern Recognition and Machine Learning* 将概率建模、决策理论、核方法和近似推断联系起来，适合查阅概率视角下的模型与推断方法。
- 周志华的《机器学习》覆盖常用模型、学习理论和实践问题，适合按任务比较方法的基本假设与用途。
- 李航的《统计学习方法（第2版）》以统计机器学习为定位，适合按模型查阅定义、算法和数学推导。
- Deisenroth、Faisal 和 Ong 的 *Mathematics for Machine Learning* 适合补充线性代数、解析几何、矩阵微积分、概率与优化等数学工具。

统计学习与学习理论

- Hastie、Tibshirani 和 Friedman 的 *The Elements of Statistical Learning* 适合查阅回归、分类、正则化、模型选择和统计学习方法。
- Shalev-Shwartz 和 Ben-David 的 *Understanding Machine Learning: From Theory to Algorithms* 适合查阅 PAC 框架、复杂度、泛化界与优化基础。
- Mohri、Rostamizadeh 和 Talwalkar 的 *Foundations of Machine Learning* 适合查阅学习界、核方法、在线学习及其理论保证。
- James、Witten、Hastie 和 Tibshirani 的 *An Introduction to Statistical Learning* 适合结合 R 实例理解回归、分类、重采样、正则化、树模型和无监督学习。

概率模型与图模型

- Murphy 的 *Machine Learning: A Probabilistic Perspective* 以概率视角组织监督学习、无监督学习、潜变量模型和图模型，适合查阅模型间的联系。

- Murphy 的 *Probabilistic Machine Learning: An Introduction* 适合查阅现代概率机器学习的统一记号、计算方法和模型实例。
- Murphy 的 *Probabilistic Machine Learning: Advanced Topics* 适合查阅深度生成模型、状态空间模型、贝叶斯优化和相关近似推断方法。
- Koller 和 Friedman 的 *Probabilistic Graphical Models: Principles and Techniques* 适合系统查阅图模型的表示、精确与近似推断以及参数和结构学习。
- Rasmussen 和 Williams 的 *Gaussian Processes for Machine Learning* 适合深入理解高斯过程、核函数、贝叶斯预测和超参数学习。

神经网络与深度学习

- Goodfellow、Bengio 和 Courville 的 *Deep Learning* 适合查阅神经网络表示、优化、正则化和深度生成模型。
- Bishop 和 Bishop 的 *Deep Learning: Foundations and Concepts* 从概率基础连接常用架构与训练方法，适合查阅相应概念和推导。
- 邱锡鹏的《神经网络与深度学习》适合查阅前馈、卷积、循环、注意力网络及其训练方法。
- Zhang、Lipton、李沐和 Smola 的 *Dive into Deep Learning* 适合结合可运行代码理解神经网络的实现、训练与调参过程。
- Géron 的 *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow* 适合查阅从数据准备、模型训练到评估和部署的实践流程。

强化学习

- Sutton 和 Barto 的 *Reinforcement Learning: An Introduction* 适合查阅马尔可夫决策过程、价值方法、策略方法与函数逼近。
- Szepesvári 的 *Algorithms for Reinforcement Learning* 适合查阅动态规划、Monte Carlo、时序差分和函数逼近算法的数学形式与分析。

应用与系统

- Manning、Raghavan 和 Schütze 的 *Introduction to Information Retrieval* 适合查阅文本表示、索引、检索模型和评价方法。
- Huyen 的 *Designing Machine Learning Systems* 从数据、训练、部署与监控讨论机器学习系统设计，适合查阅模型进入生产环境后的工程约束。

- Jurafsky 和 Martin 的 *Speech and Language Processing* 适合查阅自然语言与语音处理中的语言模型、序列标注、句法分析和语音识别。
- Szeliski 的 *Computer Vision: Algorithms and Applications* 适合查阅成像、特征、几何、识别与图像合成方法。
- Aggarwal 的 *Recommender Systems: The Textbook* 适合查阅协同过滤、基于内容的推荐、矩阵分解和推荐评价。
- Kleppmann 和 Riccomini 的 *Designing Data-Intensive Applications* 适合查阅存储、复制、分区、事务以及流式与批量处理的系统取舍。

上述教材的完整出版信息列于卷末参考文献。

数学符号

下表汇总全书反复使用的记号。各章若赋予符号更具体的含义，会在首次使用时另行说明。

对象与线性代数

对象	常用记号	含义
数集	$\mathbb{N}, \mathbb{Z}, \mathbb{R}, \mathbb{R}_+$	自然数集、整数集、实数集和非负实数集
集合与关系	$x \in A, A \subseteq B, A \cup B, A \cap B, A $	元素属于集合、子集、并集、交集和有限集合的基数
标量	$a, x, \lambda \in \mathbb{R}$	单个数值；小写斜体字母通常表示标量
向量	$\mathbf{x}, \mathbf{w} \in \mathbb{R}^d$	d 维向量；加粗小写字母表示向量
矩阵	$\mathbf{A} \in \mathbb{R}^{m \times n}, \mathbf{A}_{i,j}$	m 行 n 列矩阵及其第 i 行、第 j 列元素
数据与样本	$\mathcal{D} = \{(\mathbf{x}_i, y_i)\}_{i=1}^n$	含 n 个输入标签对的数据集；下标 i 表示样本索引
切片与迭代	$\mathbf{A}_{i,:}, \mathbf{A}_{:,j}, \mathbf{w}^{(t)}$	矩阵的第 i 行、第 j 列，以及第 t 次迭代的向量
Kronecker delta	$\delta_{i,j}$	当 $i = j$ 时取 1，否则取 0
矩阵变换	$\mathbf{A}^\top, \mathbf{A}^{-1}, \mathbf{A}^\dagger, \mathbf{I}_d, \text{tr}(\mathbf{A})$	转置、逆、伪逆、 d 阶单位矩阵和矩阵的迹
代数运算	$\langle \mathbf{x}, \mathbf{y} \rangle, \mathbf{x}^\top \mathbf{A} \mathbf{x}, \sum_i a_i, \prod_i a_i$	内积、二次型、求和与连乘
函数与模型	$f: \mathcal{X} \rightarrow \mathcal{Y}, h_{\mathbf{w}}(\mathbf{x})$	从输入空间到输出空间的函数，以及参数为 $\mathbf{w}$ 的模型
范数与距离	$\ \mathbf{x}\ _p, d(\mathbf{x}, \mathbf{y})$	p 范数与两对象之间的距离；具体定义由上下文给出

微积分与优化

对象	常用记号	含义
导数与梯度	$\frac{df}{dx}, \nabla_{\mathbf{w}} L(\mathbf{w})$	一元导数，以及标量值函数对参数向量的梯度
Jacobian 与 Hessian	$\nabla_{\mathbf{x}} \mathbf{f}, \nabla_{\mathbf{x}}^2 f$	向量值函数的一阶偏导矩阵，以及标量值函数的二阶偏导矩阵
渐近阶	$f(n) = \mathcal{O}(g(n))$	函数增长率的渐近上界
最优化	$\min_{\mathbf{w}} L(\mathbf{w}), \mathbf{w}^* \in \arg \min_{\mathbf{w}} L(\mathbf{w})$	最小目标值与取得最小值的参数；最大化使用 $\max$ 和 $\arg \max$

概率与信息论

对象	常用记号	含义
随机变量与实现	$X, \mathbf{X}, x, \mathbf{x}, p_X(x)$	随机标量、随机向量及其实现值； p_X 表示概率质量或密度函数
联合与条件概率	$p(x, y), p(x \mid y)$	随机变量实现值的联合概率与条件概率
边缘概率	$p(x) = \sum_y p(x, y), p(x) = \int p(x, y) \mathrm{d}y$	分别对离散变量求和或对连续变量积分得到的边缘概率
独立性与抽样	$X \perp Y, X \perp Y \mid Z, X_i \overset{\text{i.i.d.}}{\sim} p$	独立、给定 Z 条件独立，以及独立同分布抽样
矩与相关性	$\mathbb{E}[X], \text{Var}(X), \text{Cov}(X, Y)$	期望、方差和协方差
常用分布	$\text{Bernoulli}(p), \text{Cat}(\boldsymbol{\pi}), \mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma})$	伯努利分布、类别分布和多元高斯分布
事件指示函数	$\mathbb{I}\{A\}$	事件 A 成立时取 1，否则取 0
信息量	$H(p), H(p, q), \text{KL}(p\ q)$	熵、交叉熵和分布 p 相对于 q 的 KL 散度
概率正比关系	$p(\mathbf{x}) \propto q(\mathbf{x})$	忽略归一化常数时的概率正比关系

目录

第一部分	经典模型	1
第 1 章	经典模型简介	2
1.1	本部分的范围与组织	2
1.2	经典模型的建模思路	2
1.3	本章小结	14
第 2 章	回归	15
2.1	基于线性关系的回归	15
2.2	基于邻域的回归	39
2.3	基于树与规则的回归	47
2.4	基于概率的回归	53
2.5	基于集成的回归	61
2.6	模型选择与评价	61
2.7	本章小结	64
第 3 章	分类	65
3.1	基于线性关系的分类	65
3.2	基于邻域的分类	102
3.3	基于树与规则的分类	111
3.4	基于概率的分类	124
3.5	基于集成的分类	143
3.6	半监督分类	143
3.7	模型选择与评价	164
3.8	本章小结	166
第 4 章	聚类	167

4.1	基于原型的聚类	167
4.2	基于邻域的聚类	177
4.3	基于图的聚类	187
4.4	基于网格与子空间的聚类	192
4.5	基于层次的聚类	196
4.6	基于概率的聚类	201
4.7	基于集成的聚类	208
4.8	半监督聚类	208
4.9	模型选择与评价	214
4.10	本章小结	218
第 5 章	降维	219
5.1	基于线性关系的降维	219
5.2	基于距离的降维	240
5.3	基于邻域的降维	244
5.4	基于概率的降维	270
5.5	模型选择与评价	281
5.6	本章小结	285
第 6 章	集成学习	286
6.1	集成学习概述	286
6.2	基于 Bagging 的集成	290
6.3	基于 Boosting 的集成	294
6.4	基于 Stacking 的集成	303
6.5	成员选择与集成简化	307
6.6	模型选择与评价	309
6.7	本章小结	313
第二部分	神经网络模型	315
第 7 章	神经网络概述	316
7.1	从人工特征到可学习的表示	316
7.2	生物神经网络	321
7.3	神经网络的历史	333
7.4	神经网络的类型	335
7.5	本章小结	339

第 8 章	前馈神经网络	340
8.1	网络结构	340
8.2	参数学习	357
8.3	理论分析	367
8.4	常见应用	372
8.5	本章小结	374
第 9 章	卷积神经网络	375
9.1	卷积神经网络概述	375
9.2	卷积运算	377
9.3	网络结构	399
9.4	参数学习	411
9.5	支持更深的网络结构	414
9.6	理论分析	418
9.7	常见应用	422
9.8	本章小结	424
第 10 章	循环神经网络	426
10.1	循环神经网络概述	426
10.2	基础循环神经网络	428
10.3	基于储备池的循环神经网络	436
10.4	基于控制门的循环神经网络	440
10.5	基于注意力的循环神经网络	445
10.6	状态空间模型	448
10.7	循环神经网络的扩展	463
10.8	理论分析	468
10.9	常见应用	470
10.10	本章小结	472
第 11 章	图神经网络	473
11.1	图神经网络概述	473
11.2	基础图神经网络	475
11.3	卷积图神经网络	483
11.4	循环图神经网络	491
11.5	图神经网络的扩展	493
11.6	理论分析	497

11.7	常见应用	503
11.8	本章小结	504
第 12 章	Transformer	506
12.1	Transformer 概述	506
12.2	网络结构	510
12.3	参数学习	543
12.4	Transformer 的扩展	546
12.5	理论分析	572
12.6	常见应用	575
12.7	本章小结	578
第 13 章	脉冲神经网络	579
13.1	脉冲神经网络概述	579
13.2	网络结构	582
13.3	参数学习	588
13.4	理论分析	591
13.5	常见应用	592
13.6	本章小结	593
第 14 章	神经网络的训练	594
14.1	主要挑战	594
14.2	优化方法	599
14.3	归一化方法	615
14.4	参数与结构的改进	630
14.5	本章小结	635
第 15 章	神经网络的泛化	636
15.1	主要挑战	636
15.2	数据增强	638
15.3	模型侧的泛化控制	639
15.4	训练侧的泛化控制	641
15.5	模型集成	649
15.6	本章小结	650
第三部分	概率图模型	651

第 16 章	概率图模型概述	652
16.1	从单值预测到结构化分布	652
16.2	图模型上的表示	653
16.3	图模型上的推断与学习	655
16.4	概率图模型的演进	656
16.5	本章小结	658
第 17 章	有向图模型	659
17.1	有向图模型的定义	659
17.2	有向图的局部独立性	661
17.3	有向图的全局独立性	663
17.4	有向图中的因子分解	670
17.5	局部参数化	674
17.6	本章小结	678
第 18 章	无向图模型	679
18.1	无向图模型的定义	679
18.2	无向图的局部独立性	680
18.3	无向图的全局独立性	684
18.4	无向图中的因子分解	691
18.5	局部参数化	698
18.6	本章小结	702
第 19 章	图表示的转换与因子图	704
19.1	有向图与无向图的结构转换	704
19.2	有向图与无向图的条件独立性关系	707
19.3	有向图与无向图的因子分解关系	718
19.4	因子图	724
19.5	本章小结	728
第 20 章	基于变量消除的精确推断	730
20.1	推断问题与因子运算	730
20.2	边缘概率的变量消除算法	732
20.3	MPE 与 MAP 的变量消除算法	739
20.4	算法分析	743
20.5	本章小结	751

第 21 章	基于团树传播的精确推断	752
21.1	从变量消除到消息传递	752
21.2	树结构上的消息传递	754
21.3	团树的构造	757
21.4	团树传播	762
21.5	算法分析	768
21.6	本章小结	772
第 22 章	变分推断与确定性近似	774
22.1	变分推断的统一视角	775
22.2	近似后验分布与边缘概率	779
22.3	近似 MPE	797
22.4	本章小结	804
第 23 章	基于采样的近似推断	805
23.1	采样推断的定义	805
23.2	独立蒙特卡洛方法	807
23.3	Markov 链蒙特卡洛	811
23.4	序贯蒙特卡洛	818
23.5	算法分析	824
23.6	本章小结	828
第 24 章	参数学习	830
24.1	参数学习的定义	830
24.2	观测完整且不含潜变量的参数学习	832
24.3	观测完整但含潜变量的参数学习	838
24.4	观测缺失下的参数学习	846
24.5	基于分布估计的参数学习	848
24.6	学习算法分析	852
24.7	本章小结	855
第 25 章	结构学习	856
25.1	结构学习的定义	856
25.2	有向图结构学习	858
25.3	无向图结构学习	866
25.4	因果发现	872

25.5	算法分析	877
25.6	本章小结	879
第 26 章	静态有向模型	881
26.1	直接模型	881
26.2	潜变量模型	888
26.3	模型比较	900
26.4	本章小结	901
第 27 章	静态无向模型	902
27.1	无向模型的共同形式	902
27.2	联合能量模型	903
27.3	条件能量模型	913
27.4	模型比较	919
27.5	本章小结	920
第 28 章	动态有向模型与状态空间模型	922
28.1	动态有向模型的共同形式	922
28.2	离散状态演化模型	925
28.3	连续与混合状态演化模型	932
28.4	模型比较	941
28.5	本章小结	943
第 29 章	概率生成模型	944
29.1	概率生成模型的共同问题	944
29.2	变分自编码器	945
29.3	基于可逆变换的密度模型	950
29.4	扩散与分数生成模型	954
29.5	模型关系与比较	963
29.6	本章小结	966
参考文献		967
索引		1011

第一部分

经典模型

Classic Models

经典模型简介

同一批房屋成交记录，可以用来预测价格，也可以按预设的价格档位作分类；如果没有预设类别，还可以寻找相似房屋形成的群组，或把许多属性压缩成少数坐标。这些任务要交付的结果不同，却经常使用相近的办法：给特征加权、参考附近样本、按条件划分数据，或用概率分布解释观测。为什么同一种建模思路能够用于不同任务，换了任务以后又需要改变什么？本章为后续章节建立这条联系。

1.1 本部分的范围与组织

本书用“经典模型”组织回归、分类、聚类、降维及集成学习中的常见方法。这里的“经典”表示已经形成稳定建模主干的方法，不按发表年代划定边界。神经网络的结构与训练由第2部分展开，随机变量之间的图结构及其推断由第3部分系统讨论。概率建模本身仍贯穿本部分：贝叶斯回归、概率分类和潜变量模型都属于这里需要理解的内容。

第2章根据输入预测数值响应，第3章根据已知类别学习决策；去掉类别答案后，第4章讨论怎样发现群组，第5章讨论怎样构造较少的坐标来保留所需信息。第6章再讨论怎样把多个模型组合起来，继续服务于回归或分类等任务。因而，集成描述的是模型的组合方式，与前面四类任务的划分依据不同。

第二卷“基础、理论和可信性”的“模型简介”章已经建立模型、输出和学习准则的基本概念，第二卷“基础、理论和可信性”的“统计学习框架”章说明从训练数据选择模型与评价新样本表现的区别。本章承接这些基础，集中观察经典方法怎样表示规律。具体任务章节再说明参数怎样学习、结果怎样使用，以及什么证据能够支持相应结论。

1.2 经典模型的建模思路

以房屋数据为例，预测器可以假定面积等属性共同形成一个全局趋势，也可以主要参考相似房屋，或针对不同条件学习不同的局部规则。概率模型

进一步说明相同输入下结果可能怎样变化，集成方法则组合多个成员的判断。这些思路允许交叉：一个模型可以同时使用线性关系和概率分布，也可以把树作为集成成员。下面沿着它们各自回答的问题，说明共享结构怎样随任务改变。

1.2.1 基于线性关系的建模

预测房价时，一个直接的起点是给面积、楼龄等特征分别赋予权重，再相加得到预测。设输入为 $\mathbf{x} \in \mathbb{R}^d$ ，权重为 $\mathbf{w} \in \mathbb{R}^d$ ，偏置为 $b \in \mathbb{R}$ ，这个计算写成

$$g(\mathbf{x}) = \mathbf{w}^\top \mathbf{x} + b. \quad (1.1)$$

在线性回归中， $g(\mathbf{x})$ 可以直接作为价格预测；在二分类中，它可以作为类别得分，再按阈值给出类别。加权求和的结构相同，但回归系数需要贴合数值响应，分类权重需要帮助区分类别。得分也可以经适当转换得到类别概率，这就与后面的概率建模相接。

当目的从预测变成降维时，加权求和仍然有用，只是输出改为少数新的坐标。主成分分析（principal component analysis, PCA）选择若干投影方向，让保留的坐标描述数据的主要变化；这里学习方向的依据是输入自身的变化，而不是房价或类别标签。第5.1.1节会说明这一目标与重构误差的关系。同样的线性运算并不意味着相同的学习问题。

如果大户型和小户型的面积增量对应不同的价格变化，或面积的作用取决于楼龄，原始特征的加权就可能过于受限。可以先加入面积平方、面积与楼龄的乘积等新特征，再学习它们的权重。这种**特征映射**（feature mapping）把原来的输入改写成另一组可供计算的特征，使简单的线性组合也能表达原始输入中的非线性关系。线性因而要相对于所用的特征来判断；第2.1.1.4节从基函数展开说明这种扩展。

显式增加特征会扩大表示规模。若方法只通过特征内积使用映射后的输入，就可以直接计算这个内积，形成**核方法**（kernel method）。这种内积替换需要合法的核函数，也需要明确核矩阵怎样构造和使用。正定性的证明和 Mercer 谱展开解释内积表示为何成立，初读时可以先把握定义、条件和常用核的选择，再按需要阅读证明。

图1.1用一个二维分类例子展示特征映射 $\phi(\mathbf{x}) = (x_1, x_1^2 + x_2^2)^\top$ 。输入空间中的圆 $x_1^2 + x_2^2 = 1$ ，在新坐标中变成直线 $\phi_2 = 1$ ；同一得分 $g(\mathbf{x}) = 1 - x_1^2 - x_2^2$ 于是可以写成 $g(\mathbf{x}) = (0, -1)\phi(\mathbf{x}) + 1$ 。改变的是输入的表示，原来位于圆内与圆外的样本不需要改变类别。这幅图给定了一条可行边界，用于解释几何对应，不把它当作训练后的最大间隔解。




图 1.1 非线性边界在特征映射前后的对应，两个面板的坐标均无量纲。正类方点为 $(-0.5, 0)$ 、 $(0, 0.4)$ 、 $(0.4, 0.3)$ ，负类圆点为 $(-1.4, 0)$ 、 $(0, -1.6)$ 、 $(1.2, 0.9)$ 、 $(0.9, -1.2)$ 。右图逐点使用 $\phi_1 = x_1$ 、 $\phi_2 = x_1^2 + x_2^2$ ；水平线 $\phi_2 = 1$ 对应左图半径为 1 的圆。数据与边界均为教学构造。

1.2.1.1 特征映射与核技巧

设 $\phi: \mathbb{R}^d \rightarrow \mathcal{H}$ 把输入映射到一个 Hilbert 空间，即带有完备内积结构、可以讨论长度与正交的特征空间。若能直接计算

$$K(\mathbf{x}, \mathbf{z}) = \langle \phi(\mathbf{x}), \phi(\mathbf{z}) \rangle_{\mathcal{H}}, \quad (1.2)$$

就可以用这个函数代替显式特征内积，而不先生成 $\phi(\mathbf{x})$ 。这种替换称为**核技巧** (kernel trick)。它利用的是模型计算只依赖内积的结构，不要求把无限维向量实际存入内存。

1.2.1.2 正定条件与特征空间

相似度函数只有满足内积核的条件，才能支持上述替换。有限核矩阵的半正定性刻画一般的内积核；在紧空间、连续性和适当测度条件下，Mercer 理论进一步给出正交特征的谱展开。两种结论的条件不同，不能把 Mercer 定理的拓扑假设当成所有核方法的前提¹。

先允许输入来自任意集合 $\mathcal{X}$ 。以下定理中的 x, z 表示一般输入对象，不要求是数值向量。一个实对称函数 $K: \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}$ 称为**正定核** (positive definite kernel)，是指对任意有限输入 $x_1, \dots, x_m$ 和实系数 $a_1, \dots, a_m$ 都有

$$\sum_{i,j=1}^m a_i a_j K(x_i, x_j) \geq 0.$$

也就是说，对应的**Gram 矩阵** (Gram matrix) $\mathbf{K}_{i,j} = K(x_i, x_j)$ 半正定。这里“正定核”沿用核理论的通常名称，允许 Gram 矩阵奇异；要求互异输入与非零系数给出严格正值时，才称为严格正定核。

¹ J. Mercer, *Functions of Positive and Negative Type, and Their Connection with the Theory of Integral Equations* In Philosophical Transactions of the Royal Society of London, Series A, 1909, vol. 209, pp. 415–446

定理 1.1 正定核与 Hilbert 特征映射 对任意集合 $\mathcal{X}$ 上的实对称函数 K ，以下条件等价：

1. 任意有限输入所形成的 Gram 矩阵均为半正定矩阵。
2. 存在实 Hilbert 空间 $\mathcal{H}$ 与映射 $\phi : \mathcal{X} \rightarrow \mathcal{H}$ ，使 $K(x, z) = \langle \phi(x), \phi(z) \rangle_{\mathcal{H}}$ 。

证明. 若特征映射存在，则

$$\begin{aligned} \mathbf{a}^\top \mathbf{K} \mathbf{a} &= \sum_{i,j} a_i a_j \langle \phi(x_i), \phi(x_j) \rangle_{\mathcal{H}} \\ &= \left\| \sum_i a_i \phi(x_i) \right\|_{\mathcal{H}}^2 \geq 0, \end{aligned}$$

所以内积表示必然给出半正定 Gram 矩阵。

反过来，假设所有有限 Gram 矩阵都半正定。为每个 $x \in \mathcal{X}$ 引入一个形式基向量 $\mathbf{e}_x$ ，构造所有有限线性组合组成的向量空间 $\mathcal{V}_0$ 。若 $\mathbf{u} = \sum_i a_i \mathbf{e}_{x_i}$ 、 $\mathbf{v} = \sum_j b_j \mathbf{e}_{z_j}$ ，定义双线性形式

$$\langle \mathbf{u}, \mathbf{v} \rangle_0 = \sum_{i,j} a_i b_j K(x_i, z_j).$$

形式基向量按输入索引，重复输入的系数先合并，所以定义不依赖有限和的书写方式。对称性来自 K ，非负性来自有限 Gram 矩阵假设。唯一尚未满足的内积条件是：一个非零形式向量也可能具有零长度。

为去掉这些零长度方向，先证明它们与一切向量正交。对任意 $t \in \mathbb{R}$ ，有

$$0 \leq \langle \mathbf{u} + t\mathbf{v}, \mathbf{u} + t\mathbf{v} \rangle_0.$$

把右侧看成关于 t 的二次多项式可得 Cauchy-Schwarz 不等式 $|\langle \mathbf{u}, \mathbf{v} \rangle_0|^2 \leq \langle \mathbf{u}, \mathbf{u} \rangle_0 \langle \mathbf{v}, \mathbf{v} \rangle_0$ ；若其中一个平方长度为零，交叉内积必须为零。于是零空间

$$\mathcal{N} = \{\mathbf{u} \in \mathcal{V}_0 : \langle \mathbf{u}, \mathbf{u} \rangle_0 = 0\}$$

是线性子空间，且在商空间 $\mathcal{V}_0/\mathcal{N}$ 上， $\langle [\mathbf{u}], [\mathbf{v}] \rangle = \langle \mathbf{u}, \mathbf{v} \rangle_0$ 与代表元的选择无关。商掉零方向以后，该形式成为真正的内积。对这个内积空间作完备化，得到 Hilbert 空间 $\mathcal{H}$ 。

定义 $\phi(x) = [\mathbf{e}_x]$ ，并把这些等价类视为完备化空间中的元素，便有

$$\langle \phi(x), \phi(z) \rangle_{\mathcal{H}} = \langle \mathbf{e}_x, \mathbf{e}_z \rangle_0 = K(x, z).$$

这就直接从有限 Gram 半正定性构造出了所需特征空间。 ■

该构造还可以把 $\mathcal{H}$ 中的元素解释为函数。对 $\mathbf{u} \in \mathcal{H}$, 令 $f_{\mathbf{u}}(x) = \langle \mathbf{u}, \phi(x) \rangle_{\mathcal{H}}$ 。若这个函数处处为零, $\mathbf{u}$ 就与特征向量的稠密线性张成空间正交, 只能是零向量, 所以这种函数表示没有丢失信息。记 $K_x = K(\cdot, x)$, 对应的函数空间满足

$$f(x) = \langle f, K_x \rangle_{\mathcal{H}}, \quad |f(x)| \leq \|f\|_{\mathcal{H}} \sqrt{K(x, x)}.$$

从一个函数与核截面的内积中即可恢复该函数的点值, 这就是**再生核 Hilbert 空间** (reproducing kernel Hilbert space, RKHS) 的“再生”性质。上述一般构造属于 Moore–Aronszajn 理论; 它不依赖紧性、连续性或积分测度²。

如果希望把这种抽象特征具体写成一列正交坐标, 还需要分析一个积分算子的谱。下面给出 Mercer 谱展开的一个常用现代形式; 有限 Gram 半正定性依旧是核心假设, 而空间和测度条件保证展开能够在所有输入点上成立。

² N. Aronszajn, *Theory of Reproducing Kernels* In Transactions of the American Mathematical Society, 1950, vol. 68, no. 3, pp. 337–404

定理 1.2 连续核的 Mercer 谱展开 设 $\mathcal{X}$ 为紧度量空间, μ 为有限 Borel 测度且具有全支持, 即每个非空开集的测度都为正。若 K 为 $\mathcal{X} \times \mathcal{X}$ 上的实对称连续正定核, 则积分算子

$$(T_K f)(x) = \int_{\mathcal{X}} K(x, z) f(z) d\mu(z)$$

在 $L^2(\mu)$ 上为紧、自伴、半正定算子。它的正本征值可列为有限或可数序列 $\mu_j > 0$, 相应本征函数 ψ_j 可选为连续且在 $L^2(\mu)$ 中正交归一, 并有

$$K(x, z) = \sum_j \mu_j \psi_j(x) \psi_j(z). \quad (1.3)$$

展开在 $\mathcal{X} \times \mathcal{X}$ 上绝对且一致收敛; 零核对应空和。

证明. 利用上一构造, 先把 K 对应的 RKHS 记为 $\mathcal{H}$ 。核截面满足

$$\|K_x - K_z\|_{\mathcal{H}}^2 = K(x, x) + K(z, z) - 2K(x, z).$$

由 K 连续可知 $x \mapsto K_x$ 在 $\mathcal{H}$ 中连续, 因此每个 $f \in \mathcal{H}$ 也连续。 $\mathcal{H}$ 单位球上的函数一致有界, 且由

$$|f(x) - f(z)| \leq \|f\|_{\mathcal{H}} \|K_x - K_z\|_{\mathcal{H}}$$

得到等度连续性。Arzelà–Ascoli 定理保证这个单位球在连续函数的一致范数下相对紧; 由于 μ 有限, 嵌入算子 $J: \mathcal{H} \rightarrow L^2(\mu)$ 也是紧算子。

全支持条件使 J 单射：连续函数若在某点非零，就在该点的一个开邻域中与零保持正距离，而这个邻域测度为正，所以它不可能在 $L^2(\mu)$ 中等于零。令 $S = J^*J$ ，其中 J^* 为伴随算子，则 S 在 $\mathcal{H}$ 上紧、自伴、半正定且核空间为零。紧度量空间具有可数稠密子集，相应核截面张成的空间在 $\mathcal{H}$ 中稠密，因此 $\mathcal{H}$ 可分。由紧自伴算子的谱定理，可以取 $\mathcal{H}$ 的一组正交归一基 $\{e_j\}$ 满足

$$Se_j = \mu_j e_j, \quad \mu_j > 0.$$

若空间有限维，下述求和就是有限和。

伴随的定义与再生性质给出

$$(J^*f)(x) = \int_{\mathcal{X}} K(x, z)f(z) d\mu(z),$$

所以 $T_K = JJ^*$ ，从而具有上述紧性、自伴性与半正定性。定义 $\psi_j = e_j/\sqrt{\mu_j}$ ，则

$$\langle \psi_j, \psi_k \rangle_{L^2(\mu)} = \frac{\langle e_j, Se_k \rangle_{\mathcal{H}}}{\sqrt{\mu_j \mu_k}} = \mathbb{1}\{j = k\}, \quad T_K \psi_j = \mu_j \psi_j.$$

这里 e_j 本来就是连续函数，故 ψ_j 也有连续版本； JJ^* 的非零谱与 J^*J 一致。

对核截面 K_x, K_z 在基 $\{e_j\}$ 中使用 Parseval 恒等式，并利用 $\langle K_x, e_j \rangle_{\mathcal{H}} = e_j(x)$ ，得到

$$K(x, z) = \langle K_x, K_z \rangle_{\mathcal{H}} = \sum_j e_j(x)e_j(z) = \sum_j \mu_j \psi_j(x)\psi_j(z).$$

特别地，对角余项

$$r_m(x) = K(x, x) - \sum_{j=1}^m e_j(x)^2$$

是非负连续函数，随 m 单调下降并逐点趋于零。Dini 定理将其加强为紧空间上的一致收敛。再由 Cauchy-Schwarz 不等式，

$$\sum_{j>m} |e_j(x)e_j(z)| \leq \sqrt{r_m(x)r_m(z)} \leq \sup_{u \in \mathcal{X}} r_m(u) \longrightarrow 0.$$

因此非对角展开也绝对且一致收敛。 ■

这一谱展开给出了具体的序列特征

$$\phi(x) = (\sqrt{\mu_1}\psi_1(x), \sqrt{\mu_2}\psi_2(x), \dots)^\top \in \ell^2.$$

它确实属于平方可和序列空间，因为其平方范数为 $K(x, x) < \infty$ 。Mercer 的原始工作研究正负型函数与积分方程的联系；上面采用的是适合核学习表述的紧度量空间版本。

全支持测度在证明中的作用也已清楚：它让连续函数的逐点信息不被 L^2 等价类丢掉。对非紧输入域或不连续核，一般 Hilbert 特征映射仍可能存在，只是不能直接使用这一版本的一致谱展开。

实际设计核时，不必每次重做谱分解。非负系数加权的核之和，可用特征直和构造；两个核的乘积，可用张量积特征构造，也可由 Gram 矩阵的 Schur 乘积定理验证半正定性。若一系列正定核逐点收敛到有限值，则任意有限二次型的极限仍非负，极限也是正定核。这些闭包性质提供了可复用的构造规则。检查某一份训练集的 Gram 矩阵只能认证该有限矩阵；要使核在新样本上也合法，还需要针对整个定义域的证明或已知构造。

1.2.1.3 常用核与表示选择

回到 $\mathbf{x}, \mathbf{z} \in \mathbb{R}^d$ 。常用核之间的区别主要在于怎样度量接近程度、允许哪些特征交互，以及这些选择带来怎样的函数范数。表1.1列出五种常见形式，核尺度统一记为 β ，多项式次数记为 p ，避免与输入维数 d 混用。

名称	$K(\mathbf{x}, \mathbf{z})$	参数与正定性
线性核	$\mathbf{x}^\top \mathbf{z}$	半正定
多项式核	$(\beta \mathbf{x}^\top \mathbf{z} + r)^p$	$\beta, r \geq 0$, 正整数 p
高斯 RBF 核	$\exp(-\beta \ \mathbf{x} - \mathbf{z}\ _2^2)$	$\beta > 0$, 半正定
Laplacian 核	$\exp(-\beta \ \mathbf{x} - \mathbf{z}\ _1)$	$\beta > 0$, 半正定
Sigmoid 形式	$\tanh(\beta \mathbf{x}^\top \mathbf{z} + r)$	一般不保证半正定

表 1.1 常用核函数与合法性条件。这里的“半正定”要求任意有限输入的 Gram 矩阵半正定；Sigmoid 一行列出的是常见相似性形式，使用前仍需针对定义域与参数检验。

线性核 (linear kernel) 对应 $\phi(\mathbf{x}) = \mathbf{x}$ ，保留原始特征内积。对于线性预测，训练样本的核展开可以聚合为一个权重向量，使用时不必逐一访问这些样本。是否需要额外的非线性交互，应通过任务与验证数据判断；输入维数高本身既不保证线性结构足够，也不意味着非线性核必然更好。

多项式核 (polynomial kernel) 把有限阶交互隐式加入模型。以 $d = 2$ 、 $\beta = 1$ 、 $r = 0$ 、 $p = 2$ 为例，

$$(\mathbf{x}^\top \mathbf{z})^2 = x_1^2 z_1^2 + 2x_1 x_2 z_1 z_2 + x_2^2 z_2^2,$$

$$\phi(\mathbf{x}) = (x_1^2, \sqrt{2} x_1 x_2, x_2^2)^\top.$$

交叉项前的 $\sqrt{2}$ 使特征内积准确等于核值。一般地，令多重指标 $\mathbf{a} = (a_1, \dots, a_d)$ 满足 $|\mathbf{a}| = \sum_j a_j = p$ ，并记 $\mathbf{x}^{\mathbf{a}} = \prod_j x_j^{a_j}$ 、 $\mathbf{a}! = \prod_j a_j!$ 。多项

式展开为

$$(\mathbf{x}^\top \mathbf{z})^p = \sum_{|\mathbf{a}|=p} \frac{p!}{\mathbf{a}!} \mathbf{x}^{\mathbf{a}} \mathbf{z}^{\mathbf{a}}.$$

所以齐次 p 次核可以使用 $\binom{d+p-1}{p}$ 个单项式坐标；当 $\beta > 0, r > 0$ 时，非齐次核包括 0 至 p 次项，一种完整单项式表示的维数是 $\binom{d+p}{p}$ 。这些是特征数量，不是样本数量；计算一个核值通常只需一次 d 维内积和幂运算，节省的是显式特征展开成本，完整优化仍要另计。

高斯径向基核 (Gaussian radial basis function kernel, Gaussian RBF kernel) 根据欧氏距离赋予局部相似性。其无限维特征可以由指数级数直接看出：

$$K(\mathbf{x}, \mathbf{z}) = e^{-\beta \|\mathbf{x}\|_2^2} e^{-\beta \|\mathbf{z}\|_2^2} \cdot \sum_{p=0}^{\infty} \frac{(2\beta)^p}{p!} (\mathbf{x}^\top \mathbf{z})^p. \quad (1.4)$$

每一阶多项式核都是半正定的，系数非负，两个单点因子可以吸收到特征中；级数逐点收敛，因而也给出了高斯核合法性的证明。把每一阶的单项式展开合并，坐标可写成

$$\phi_{\mathbf{a}}(\mathbf{x}) = e^{-\beta \|\mathbf{x}\|_2^2} \sqrt{\frac{(2\beta)^{|\mathbf{a}|}}{\mathbf{a}!}} \mathbf{x}^{\mathbf{a}}, \quad \mathbf{a} \in \mathbb{N}_0^d.$$

这里 $\mathbb{N}_0$ 为非负整数集合，所有坐标平方之和等于 $K(\mathbf{x}, \mathbf{x}) = 1$ 。在整个 $\mathbb{R}^d$ 上，这个核具有无限秩；限制到一批有限训练点以后，实际使用的 Gram 矩阵仍是 $n \times n$ 。

参数 β 控制相似性随距离衰减的速度，也常写成 $\beta = 1/(2\sigma^2)$ 。较大 β 使不同训练点之间的相似性迅速减小，模型能够形成更局部的变化；较小 β 使作用范围更宽。对互异有限输入，高斯 Gram 矩阵严格正定，因此在不约束范数时，线性方程 $\mathbf{K}\mathbf{a} = \mathbf{y}$ 允许核展开插值给定标签。然而所需系数与函数范数可能很大；固定范数、固定正则化强度或有重复输入且标签冲突时，都不能由“无限维”推出任意插值，更不能由插值推出泛化良好。

Laplacian 核 (Laplacian kernel) 使用 L^1 距离，且可以分解成各坐标上的乘积：

$$\exp(-\beta \|\mathbf{x} - \mathbf{z}\|_1) = \prod_{j=1}^d \exp(-\beta |x_j - z_j|).$$

一维形式的半正定性可由积分特征表示验证：

$$e^{-\beta |t|} = \int_{\mathbb{R}} e^{i\omega t} \frac{\beta}{\pi(\beta^2 + \omega^2)} d\omega.$$

其中 i 为虚数单位。对任意有限个输入 x_j 和实系数 a_j ，将有限求和移入

积分可得

$$\begin{aligned} & \sum_{j,k} a_j a_k e^{-\beta|x_j-x_k|} \\ &= \int_{\mathbb{R}} \left| \sum_j a_j e^{i\omega x_j} \right|^2 \frac{\beta}{\pi(\beta^2 + \omega^2)} d\omega \geq 0. \end{aligned}$$

多维形式再由核的乘积闭包得到。Laplacian 核在零距离附近的变化方式与高斯核不同，可以作为直方图或稀疏特征上的另一种距离选择，但哪一种更适合仍取决于尺度、表示与验证结果。

常称为**Sigmoid 核**（sigmoid kernel）的形式将内积送入双曲正切函数，形态上接近一个具有非线性激活的神经元，却不自动具有内积核的性质。甚至 $\beta = 1, r = 0$ 也不能在整个实数域上保证半正定：对 $x_1 = 1, x_2 = 2$ ，二阶 Gram 行列式为

$$\tanh(1)\tanh(4) - \tanh(2)^2 \approx -0.1683 < 0.$$

因此“参数取正”并不足以保证合法。某个有限数据集上矩阵没有负特征值，只说明当前矩阵通过检查；若要保留依赖内积核的几何与优化解释，应选用在目标定义域上已确认半正定的核。

对字符串、图与树，核技巧同样适用。**字符串核**（string kernel）可以计数共同的子串或子序列，**图核**（graph kernel）可以比较局部子结构，**树核**（tree kernel）可以比较子树模式。若将每种模式的出现次数作为一个坐标，两对象的模式计数内积就给出了直接的正定构造；动态规划或结构化计数有时能避免把全部坐标显式列出。这样的**结构化核**（structured kernel）把输入的组合结构用于相似性计算，适用于序列分析、分子图或句法树等场景，并通过可验证的特征内积保留核方法的几何与优化性质。

1.2.1.4 核矩阵的使用与中心化

在 n 个训练输入上，核矩阵的元素为 $\mathbf{K}_{i,j} = K(\mathbf{x}_i, \mathbf{x}_j)$ 。完整存储需要 $O(n^2)$ 空间和 $O(n^2)$ 次核计算；显式特征可以很大甚至无限维，并不意味着样本之间的计算也消失了。缓存、稀疏化或低秩近似会改变实现成本，近似误差仍须与具体任务一起评价。

有些方法要求在特征空间中先减去训练均值。令 $\mathbf{1} \in \mathbb{R}^n$ 为全一向量、 $\mathbf{I}_n$ 为单位矩阵，中心化矩阵及中心化核矩阵为

$$\mathbf{H} = \mathbf{I}_n - \frac{1}{n}\mathbf{1}\mathbf{1}^\top, \quad \mathbf{K}_c = \mathbf{H}\mathbf{K}\mathbf{H}. \quad (1.5)$$

左乘 $\mathbf{H}$ 减去各列均值，右乘 $\mathbf{H}$ 减去各行均值；展开双边乘积时，还要加回原核矩阵的整体均值。结果等于中心化特征的内积矩阵。只对原始输入作中心化，一般不能代替非线性特征中心化。新样本也应使用训练特征的均

值，不能重新用测试数据定义中心。中心化是否必要由具体目标决定，例如核 PCA 需要它，高斯过程的协方差建模则不因此一律先作这种变换。

核支持向量分类器在特征空间中学习分界，核支持向量回归拟合数值响应，核 PCA 保留特征空间方差，核 K-means 则优化特征空间的簇内距离。四者共享核定义的几何，但学习目标不同；相应入口见第3.1.3.5、第2.1.4.4、第5.1.7和第4.1节。非线性表达来自映射，映射是否适合任务仍需结合数据判断。

1.2.2 基于邻域的建模

另一种做法是直接寻找与待预测房屋相似的成交记录。**邻域** (neighborhood) 指按选定距离或相似关系找到的一组附近样本；模型主要利用这些样本的信息，而不必为所有房屋规定同一个全局趋势。 k 近邻 (k -nearest neighbors, k -NN) 用最近的 k 个样本构成邻域：回归时可以平均它们的价格，分类时可以让它们的类别投票，也可以给更近的样本更大权重。改变的是聚合的对象和产生输出的规则，寻找邻居的计算则可以复用。

没有响应或类别时，邻域还可以提供样本之间的结构证据。密度聚类考察一个位置附近是否有足够多的样本，再按相应规则连接稠密区域；基于图的方法把样本作为节点，把选定的相似关系作为边。图结构可以用于寻找群组，也可以在少量样本有标签时约束标签传播。用于降维时，则可以要求原本相近的样本在低维表示中仍保持邻近。距离、邻域和图因此连接了预测、聚类与表示学习，但“同一簇”“同一类别”和“相近坐标”仍是不同的要求。

也可以用少量**原型** (prototype) 代表样本群体，再按到原型的距离作判断。最近质心分类器用类别中心比较输入，K-means 则在没有类别标签时同时学习中心和簇分配。两者都比较样本与代表，但前者的类别已知，后者需要寻找分组；原型也不等同于查询点的局部邻居。第3.2.2节与第4.1节分别讨论这些使用方式。

这些做法都依赖“相近”的含义。**相异度** (dissimilarity) 用较小值表示更相近，不一定满足距离度量的全部条件；需要三角不等式的计算不能直接用于任意相异度。房屋在面积上接近，却可能位于不同地区；把面积、楼龄和位置直接混在一个距离中，也可能让数值尺度较大的属性主导邻居选择。表示和度量决定邻域，邻域再影响预测、连通与布局。第2.2节和第3.2节比较局部预测，第4.2节与第4.3节讨论群组结构，第5.3节讨论低维布局应保留哪些邻域关系。

1.2.3 基于树与规则的建模

如果不同房屋适合采用不同的预测规则，可以通过具体条件划分输入。例如，对某个地区的房屋按面积划分，再对其中一组按楼龄划分。**决策树** (decision tree) 把这些条件组织成逐层分支的结构：输入沿分支到达一个叶节点，再使用该叶的预测。每条路径规定一个区域，不同区域可以采用不同的局部判断。

回归树和分类树共享这套划分结构。采用平方损失时，常数叶的回归树在叶内给出响应均值；分类树可以给出类别或类别比例。因为要拟合的目标不同，选择分裂的准则也随之改变。回归还可以在叶内拟合线性模型，使一片区域既有条件边界，也有局部趋势。这里同时用到了分区和线性关系，说明建模思路可以组合。第2.3节与第3.3节分别展开这些训练与预测过程。

树路径也可以写成“如果若干条件成立，就给出某个结论”。**规则模型** (rule-based model) 直接学习和组织这类条件，规则之间可以重叠，也可能有优先顺序，不必形成一棵完整的树。第3.3.4节会说明怎样处理覆盖、冲突和默认类别。浅树或短规则便于检查具体条件，但随着分支或规则数量增加，理解整个决策过程也会变得困难；只凭表示形式不能认定一个模型已经容易解释。

树还可以组织嵌套群组。层次聚类逐步合并或分裂样本组，保留不同粒度下的包含关系；其树描述分组层次，决策树的分支则描述输入条件与预测路径。二者都使用树形结构，但学习准则与输出不同，不能直接共用分类树的分裂规则，详见第4.5节。

1.2.4 基于概率的建模

同样面积、楼龄和位置的房屋，成交价格仍会变化。只输出一个数值，会省去这种变化的描述。**概率建模** (probabilistic modeling) 为相关变量建立概率分布，用分布说明哪些结果更可能出现，以及结果可能怎样分散。回归可以描述给定输入后的响应分布，也可以对未知系数或函数设置先验，再根据观测形成后验。响应本身的变化与有限数据造成的估计不确定性由此有了不同的建模位置；第2.4节进一步说明这一差别。

分类关注的则是给定输入后的类别概率。可以直接建立这一条件分布，也可以先描述各类别内部的输入分布及类别出现的比例，再通过贝叶斯公式计算类别概率。前一种思路通向 Logistic 回归等条件模型，后一种思路通向朴素贝叶斯等生成式分类器。朴素贝叶斯用“给定类别后各特征条件独立”的假设简化联合分布，这个假设不等于说所有房屋属性在总体中互不相关。第3.4节比较这些分布设定怎样改变训练与决策。

若类别没有给出，可以把群组归属作为**潜变量** (latent variable)，即参与

解释观测、却没有直接记录在数据中的随机量。高斯混合模型（Gaussian mixture model, GMM）用多个成分分布共同描述输入，并估计一个样本属于各成分的概率；聚类结果的含义依赖这些成分是否适合所要寻找的群组。降维中的潜变量承担另一种职责：它是少量潜在坐标，模型用这些坐标及噪声生成高维观测。概率主成分分析把这一生成关系设为线性，高斯过程潜变量模型则允许非线性映射。第4.6.1节与第5.4节会分别说明离散群组和低维坐标的作用。

概率因此可以与前面的表示方式结合。贝叶斯线性回归仍使用线性函数，高斯过程通过核描述函数值之间的协方差，潜变量模型可以把线性或非线性映射写进生成过程。但模型给出了概率，不意味着这些概率已经符合真实数据；分布假设、参数估计与校准仍影响它们的解释。有关概率输出的经验检验可回看第二卷“基础、理论和可信性”的“可靠性”章“概率与预测范围的检验”小节。

1.2.5 基于集成的建模

同一个预测任务可以训练出不同模型。一棵树可能对训练样本的少量变化很敏感，一个简单线性模型也可能留下系统性的预测误差。**集成学习**（ensemble learning）通过训练多个成员并组合它们的输出，改变整体模型的预测方式。成员通常称为**基学习器**（base learner）；组合能否带来收益，既取决于成员各自的表现，也取决于它们是否反复犯相同的错误。

针对训练扰动，可以从原训练集有放回地抽取多份数据，通常每份与原训练集的样本数相同，分别训练成员，再平均回归预测或汇总分类投票。这种自助采样聚合称为**装袋法**（bootstrap aggregating, Bagging）：用重采样产生不同成员，用聚合减弱不稳定预测的波动。随机森林还在节点分裂时随机选择候选特征，让各棵树在不同的信息条件下生长。成员共享相近的任务和模型形式，但不需要得到相同的划分；误差相关性仍会限制聚合的收益³。第6.2节将进一步解释自助样本、袋外预测和树成员随机化。

针对尚未拟合好的部分，可以让新成员接着已有预测训练。**Boosting**（提升）逐轮加入成员，使后续学习回应当前整体模型的不足。AdaBoost 依据当前分类错误重新加权样本，让分错的样本在下一轮更受重视；梯度提升则根据所选损失确定每一轮应拟合的修正方向，平方损失回归中的修正可以直接表现为当前残差。任务与损失改变后，修正的含义也会改变，所以“每轮拟合残差”不能概括所有 Boosting 方法。弱学习与提升的理论联系见第二卷“基础、理论和可信性”的“二分类学习的可学习性”章“集成学习”节，前向逐步建模和现代梯度提升树见第6.3节⁴。

如果线性模型、近邻和树各有可用信息，还可以学习怎样利用它们的预测。**Stacking**（堆叠）把基学习器的预测作为另一层模型的输入，由这个**元学习器**（meta-learner）学习组合规则。训练组合层时，需要让每个样本对

³ L. Breiman, *Bagging Predictors In Machine Learning*, 1996, vol. 24, no. 2, pp. 123–140; L. Breiman, *Random Forests In Machine Learning*, 2001, vol. 45, no. 1, pp. 5–32

⁴ J. H. Friedman, *Greedy Function Approximation: A Gradient Boosting Machine In The Annals of Statistics*, 2001, vol. 29, no. 5, pp. 1189–1232

应的基预测来自未使用该样本拟合的模型，例如交叉验证中的折外预测；否则，组合层容易学到基模型在训练样本上的过度乐观表现。**Stacking** 可以混合不同类型的成员，但也增加了训练步骤和预测时需要运行的模型数量；完整训练与部署流程见第6.4节⁵。

⁵ D. H. Wolpert, *Stacked Generalization* In *Neural Networks*, 1992, vol. 5, no. 2, pp. 241–259

1.3 本章小结

回到房屋数据，不同任务决定要预测价格、判断类别、发现群组还是保留表示；建模思路则决定采用什么关系完成这些目标。一个加权和可以是价格预测、类别得分或低维坐标，一个邻域可以提供响应、标签或结构证据。共享计算需要与任务目标一起理解，不能仅由方法名称推断输出含义。

这些思路也不是相互排斥的选择。线性关系可以借助特征映射与核扩展，局部区域可以包含线性模型，概率分布可以附着在线性或核表示上，多个成员还可以进一步集成。后续章节将以具体任务为依据，说明这些组合怎样学习、怎样评价，以及在什么条件下适用。从第2章开始，数值响应提供了观察这些差异的具体起点。

回归

预测房屋价格时，可以估计平均成交价，也可以给出预算所需的上分位数或价格分布。**回归**（regression）根据输入估计数值响应的这些条件特征。设训练集为 $D_n = \{(\mathbf{x}_i, y_i)\}_{i=1}^n$ ，其中 $\mathbf{x}_i \in \mathbb{R}^d$ 为输入， $y_i \in \mathbb{R}$ 为响应，预测函数记为 f ；响应也可以是次数等离散数值。

回归的计算起点可追溯到19世纪初的最小二乘法，“回归”这一名称则来自 Galton 在1886年对亲子身高的研究。1970年代的广义线性模型扩展了响应类型，1980年代的回归树表达条件分区，1990年代的支持向量回归及随后发展的树集成进一步容纳非线性与交互¹。

如今，需要检查变量作用或建立简洁基线时，线性模型仍是常见起点；面对复杂表格数据，随机森林与梯度提升树是常用候选。现代基准也表明，梯度提升树仍有竞争力，但表现取决于数据、调参与计算预算，不能据此认定一种模型总占优势²。

本章依次介绍基于线性关系、邻域、树与规则、概率和集成的回归：分别用全局加权、局部样本、条件分区、分布与后验、成员组合来预测响应。共享机制见第1章，这里展开各自的目标、学习过程与适用条件。

2.1 基于线性关系的回归

第1.2.1节的加权和在这里用于预测数值响应。本节从最小二乘开始，再通过正则化控制系数、通过损失选择均值或分位数目标、通过核扩展函数表示。广义线性模型与可加模型进一步改变响应分布或特征作用；高斯误差只属于其中的特定设定。

2.1.1 普通最小二乘 (OLS)

从样本中选择一组系数，需要先规定怎样衡量预测误差。**普通最小二乘**（ordinary least squares, OLS）选择使残差平方和最小的系数。它既可以作为一个无需指定响应分布的优化准则，也可以在高斯噪声模型下解释为最大似然估计；以下先建立前一种形式，再说明统计结论需要哪些额外条

¹ F. Galton, *Regression Towards Mediocrity in Hereditary Stature* In The Journal of the Anthropological Institute of Great Britain and Ireland, 1886, vol. 15, pp. 246–263; J. A. Nelder, R. W. M. Wedderburn, *Generalized Linear Models* In Journal of the Royal Statistical Society: Series A (General), 1972, vol. 135, no. 3, pp. 370–384; L. Breiman, J. H. Friedman, R. A. Olshen, C. J. Stone, *Classification and Regression Trees*, Wadsworth International Group, 1984, 1st ed.

² N. Erickson, L. Purucker, A. Tschalzev, D. Holzmüller, P. Mutalik Desai, D. Salinas, F. Hutter, *TabArena: A Living Benchmark for Machine Learning on Tabular Data* In Advances in Neural Information Processing Systems, 2026, vol. 38

件³。

这种误差准则早于“回归”的名称。Legendre 在 1805 年公开发表最小二乘法时，面对的是观测方程多于未知量、各方程通常无法同时精确成立的问题；误差平方和提供了在不一致观测之间取舍的准则。Gauss 在 1809 年的天体轨道著作中又从观测误差的概率分析出发讨论其依据⁴。

2.1.1.1 模型结构

令 $\phi(\mathbf{x}) \in \mathbb{R}^p$ 表示固定特征向量，模型写成 $f_{\mathbf{w}}(\mathbf{x}) = \phi(\mathbf{x})^\top \mathbf{w}$ ，其中 $\mathbf{w} \in \mathbb{R}^p$ 。最简单的选择是 $\phi(\mathbf{x}) = (1, \mathbf{x}^\top)^\top$ ，此时 $p = d + 1$ ，第一个系数为截距。这里的“线性”指预测对待估计系数线性；特征变换 ϕ 可以非线性，其具体形式将在本小节后面展开。

把样本堆叠为设计矩阵 $\mathbf{X} \in \mathbb{R}^{n \times p}$ ，第 i 行为 $\phi(\mathbf{x}_i)^\top$ ，并记 $\mathbf{y} = (y_1, \dots, y_n)^\top$ ，得到目标

$$\hat{\mathbf{w}} \in \arg \min_{\mathbf{w}} J(\mathbf{w}), \quad J(\mathbf{w}) = \frac{1}{2n} \|\mathbf{y} - \mathbf{X}\mathbf{w}\|_2^2. \quad (2.1)$$

因子 $1/(2n)$ 不改变 OLS 的最优解，但会影响梯度、步长和正则系数的数值约定。本章使用平均平方损失时均沿用这一形式。

图2.1把这个目标放回输入与响应平面：每条虚线都是固定 x_i 之后，观测 y_i 与直线预测之间的纵向差。OLS 选择的是让这些差的平方和最小的直线，因此拟合线通常不穿过每个样本；这里测量的也不是点到直线的垂直几何距离。




图 2.1 一维 OLS 与响应残差。七个构造样本的最小二乘直线为 $\hat{f}(x) = 1 + 0.5x$ ；蓝色实心点表示观测，黄色实线表示预测，红色竖虚线表示 $r_i = y_i - \hat{f}(x_i)$ 。横、纵轴均为无量纲教学变量。

平方损失为什么适合预测均值？设 $(\mathbf{X}_{\text{new}}, Y)$ 为新观测， $\mathbb{E}[Y^2] < \infty$ ， $m(\mathbf{x}) = \mathbb{E}[Y | \mathbf{X}_{\text{new}} = \mathbf{x}]$ 。对平方可积的 f ，将 $Y - f$ 拆成 $Y - m + m - f$

³ C. M. Bishop, *Pattern Recognition and Machine Learning*, Springer, 2006, 1st ed.

⁴ S. M. Stigler, *Gauss and the Invention of Least Squares* In *The Annals of Statistics*, 1981, vol. 9, no. 3, pp. 465–474; C. F. Gauss, *Theoria motus corporum coelestium in sectionibus conicis solem ambientium*, Perthes et Besser, 1809

并平方，利用 $\mathbb{E}[Y - m(\mathbf{X}_{\text{new}}) | \mathbf{X}_{\text{new}}] = 0$ 消去交叉项，便有

$$\begin{aligned} \mathbb{E}[(Y - f(\mathbf{X}_{\text{new}}))^2] &= \mathbb{E}[\text{Var}(Y | \mathbf{X}_{\text{new}})] \\ &\quad + \mathbb{E}[(m(\mathbf{X}_{\text{new}}) - f(\mathbf{X}_{\text{new}}))^2]. \end{aligned} \quad (2.2)$$

第一项不随 f 变化，第二项在 $f = m$ 几乎处处成立时最小。因此平方损失的总体目标是条件均值，不要求误差对称、同方差或高斯。限制为线性表示以后，若 m 不在模型类中，得到的只是该类中的最佳平方逼近。

2.1.1.2 参数学习

目标的梯度为 $\mathbf{X}^\top(\mathbf{X}\mathbf{w} - \mathbf{y})/n$ ，Hessian 为 $\mathbf{X}^\top\mathbf{X}/n$ ，后者半正定。因此使梯度为零既是必要条件，也是充分条件，得到**正规方程**（normal equations）：残差与每一列特征都正交。

$$\mathbf{X}^\top\mathbf{X}\hat{\mathbf{w}} = \mathbf{X}^\top\mathbf{y}. \quad (2.3)$$

定理 2.1 最小二乘解的存在与唯一性 任意有限设计矩阵的 OLS 问题都有解，拟合值 $\mathbf{X}\hat{\mathbf{w}}$ 唯一。参数解唯一当且仅当 $\mathbf{X}$ 列满秩；此时

$$\hat{\mathbf{w}} = (\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top\mathbf{y}.$$

一般情形下，全部解为 $\mathbf{X}^\dagger\mathbf{y} + \mathbf{v}$ ，其中 $\mathbf{X}\mathbf{v} = \mathbf{0}$ ； $\mathbf{X}^\dagger\mathbf{y}$ 是欧氏范数最小的解。

证明. 有限维列空间是闭子空间，故 $\mathbf{y}$ 在其上的正交投影存在且唯一。任取表示这个投影的系数 $\hat{\mathbf{w}}$ ，正交条件给出式(2.3)。对任意扰动 $\mathbf{v}$ ，

$$\|\mathbf{y} - \mathbf{X}(\hat{\mathbf{w}} + \mathbf{v})\|_2^2 = \|\mathbf{y} - \mathbf{X}\hat{\mathbf{w}}\|_2^2 + \|\mathbf{X}\mathbf{v}\|_2^2,$$

所以解的差恰好来自 $\mathbf{X}$ 的零空间。零空间只含零向量等价于列满秩，此时正规方程给出所述逆矩阵公式。

取紧致奇异值分解 $\mathbf{X} = \mathbf{U}_r\mathbf{D}_r\mathbf{V}_r^\top$ ，其中 r 是秩， $\mathbf{D}_r$ 的对角元为正。系数 $\mathbf{V}_r\mathbf{D}_r^{-1}\mathbf{U}_r^\top\mathbf{y} = \mathbf{X}^\dagger\mathbf{y}$ 给出上述投影。它属于行空间，与零空间正交，因此加上任何非零 $\mathbf{v}$ 都会增大系数范数。 ■

闭式表达用于分析，计算时通常不显式求逆。列满秩且 $n \geq p$ 时，薄 QR 分解 $\mathbf{X} = \mathbf{Q}\mathbf{R}$ 把问题化为三角方程 $\mathbf{R}\hat{\mathbf{w}} = \mathbf{Q}^\top\mathbf{y}$ ，稠密计算代价约为 $O(np^2)$ 。秩亏或需要检查小奇异值时可以用 SVD。直接形成 $\mathbf{X}^\top\mathbf{X}$ 会把满秩矩阵的二范数条件数平方，因此近似共线时尤其应避免求逆实现。

当矩阵分解不便进行时，可迭代更新

$$\mathbf{w}^{(t+1)} = \mathbf{w}^{(t)} + \frac{\eta}{n} \mathbf{X}^T (\mathbf{y} - \mathbf{X} \mathbf{w}^{(t)}). \quad (2.4)$$

一次完整更新需要 $O(np)$ 次算术操作；使用大小为 b 的小批量时，一次梯度估计需 $O(bp)$ ，但总更新次数和随机误差也须考虑。代码2.1展示矩阵求解接口与预测；截距列需由调用者加入，返回的秩可用于检查参数是否可识别。

代码 2.1 用最小二乘接口求解并预测

```
1 import numpy as np
2
3 # X: (n, p), y: (n,), X_new: (n_new, p)
4 # 截距列与特征变换在训练、预测时保持一致。
5 w, residuals, rank, singular_values = np.linalg.lstsq(
6     X, y, rcond=None
7 )
8 y_pred = X_new @ w
```

2.1.1.3 理论分析

OLS 的计算结论与统计结论依赖不同的随机性。固定设计下可以分别考察优化误差和参数估计误差；转到独立同分布的随机设计，讨论的则是估计量的渐近分布。下面得到的结论包括确定性收敛、条件均方误差和依概率或依分布的极限，但不能据此保证模型失配或任意测试分布下的风险。

收敛性分析 优化收敛描述算法能否求到经验目标的最小点。记 $\mathbf{A} = \mathbf{X}^T \mathbf{X} / n$ ，满秩时梯度下降的参数误差满足 $\mathbf{e}^{(t+1)} = (\mathbf{I} - \eta \mathbf{A}) \mathbf{e}^{(t)}$ 。若 $\mathbf{A}$ 的特征值为 $a_j > 0$ ，取 $0 < \eta < 2 / \max_j a_j$ ，每个特征方向上的误差都乘以绝对值小于 1 的因子 $1 - \eta a_j$ ，从而线性收敛。秩亏时，零空间分量保持初值；从零初始化，在非零谱上采用同样步长条件便收敛到最小范数解。设计全为零时目标与参数无关，零初始化已是最小范数解。

泛化分析 求到经验最优解后，还需考察有限样本造成的估计误差及其对新输入预测的影响。偏差与方差分析需要指定响应如何产生。以下条件于固定设计，假设

$$\mathbf{y} = \mathbf{X} \mathbf{w}_* + \boldsymbol{\varepsilon}, \quad \mathbb{E}[\boldsymbol{\varepsilon} \mid \mathbf{X}] = \mathbf{0}, \quad \text{Cov}(\boldsymbol{\varepsilon} \mid \mathbf{X}) = \sigma^2 \mathbf{I}_n. \quad (2.5)$$

这些条件要求均值模型正确、误差同方差且两两不相关；不相关不等于独立，也没有要求高斯分布。

定理 2.2 Gauss-Markov 定理 在式(2.5)下, 若 $\mathbf{X}$ 列满秩, OLS 无偏, 协方差为 $\sigma^2(\mathbf{X}^\top \mathbf{X})^{-1}$ 。对任何条件于 $\mathbf{X}$ 固定、对所有 $\mathbf{w}_\star$ 均无偏的线性估计 $\tilde{\mathbf{w}} = \mathbf{C}\mathbf{y}$, 有

$$\text{Cov}(\tilde{\mathbf{w}} | \mathbf{X}) - \text{Cov}(\hat{\mathbf{w}} | \mathbf{X}) \geq \mathbf{0}.$$

证明. 记 $\mathbf{C}_0 = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top$ 。由 $\mathbf{C}_0 \mathbf{X} = \mathbf{I}$ 得到 OLS 的无偏性与协方差。另一方面, $\mathbf{C}\mathbf{y}$ 对所有真参数无偏要求 $\mathbf{C}\mathbf{X} = \mathbf{I}$ 。令 $\mathbf{D} = \mathbf{C} - \mathbf{C}_0$, 则 $\mathbf{D}\mathbf{X} = \mathbf{0}$, 并有

$$\mathbf{C}_0 \mathbf{D}^\top = (\mathbf{X}^\top \mathbf{X})^{-1} (\mathbf{D}\mathbf{X})^\top = \mathbf{0}.$$

将 $\mathbf{C} = \mathbf{C}_0 + \mathbf{D}$ 代入协方差, 交叉项消失, 差矩阵为 $\sigma^2 \mathbf{D}\mathbf{D}^\top$ 。对任意 $\mathbf{a}$, 其二次型等于 $\sigma^2 \|\mathbf{D}^\top \mathbf{a}\|_2^2 \geq 0$, 故半正定。 ■

这里的“最优”限定在线性无偏估计的协方差比较中, 不涉及所有预测算法。对固定新特征 $\phi_\star$, 估计条件均值的均方误差为 $\sigma^2 \phi_\star^\top (\mathbf{X}^\top \mathbf{X})^{-1} \phi_\star$; 若预测带独立同方差噪声的未来响应, 还要加上 σ^2 。设计的小特征值方向和远离训练范围的查询点都可能放大预测误差。

异方差不会在零条件均值下破坏 OLS 无偏性, 但会改变协方差。若已知正定误差协方差 Ω , 最小化 $(\mathbf{y} - \mathbf{X}\mathbf{w})^\top \Omega^{-1} (\mathbf{y} - \mathbf{X}\mathbf{w})$ 得到**广义最小二乘** (generalized least squares, GLS), 即按噪声结构重新度量残差; 对角 Ω 对应加权最小二乘。用 $\Omega^{-1/2}$ 变换数据即可回到同方差问题。若协方差也需估计, 须另行考虑其误差。

固定维数下的一致性可以直接由协方差得到。若固定设计序列满足 $\mathbf{X}^\top \mathbf{X}/n \rightarrow \mathbf{Q} > 0$, 并在每个 n 下满足式(2.5), 则

$$\mathbb{E}[\|\hat{\mathbf{w}} - \mathbf{w}_\star\|_2^2 | \mathbf{X}] = \frac{\sigma^2}{n} \text{tr}((\mathbf{X}^\top \mathbf{X}/n)^{-1}) \rightarrow 0.$$

均方一致性进而给出依概率一致性。渐近正态性还需要中心极限定理的条件。例如, 设样本对 $(\mathbf{z}_i, \varepsilon_i)$ 独立同分布, 其中 $\mathbf{z}_i = \phi(\mathbf{x}_i)$ 。若其共同分布满足 $\mathbb{E}\|\mathbf{z}\|_2^2 < \infty$, $\mathbf{Q} = \mathbb{E}[\mathbf{z}\mathbf{z}^\top] > 0$, 且 $\mathbb{E}[\varepsilon | \mathbf{z}] = 0$, $\mathbb{E}[\varepsilon^2 | \mathbf{z}] = \sigma^2 < \infty$, 则

$$\sqrt{n}(\hat{\mathbf{w}} - \mathbf{w}_\star) = (\mathbf{X}^\top \mathbf{X}/n)^{-1} \frac{1}{\sqrt{n}} \sum_i \mathbf{z}_i \varepsilon_i \xrightarrow{d} \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{Q}^{-1}).$$

这里分别对 Gram 矩阵使用大数定律、对独立的 $\mathbf{z}_i \varepsilon_i$ 使用多元中心极限定理, 再用 Slutsky 定理合并。仅有误差不相关并不足以直接调用该中心极限定理。若误差条件高斯, OLS 在有限样本下已经具有相应高斯分布, 并与高斯似然的最大似然估计一致。

2.1.1.4 支持非线性映射（多项式回归与基函数展开）

价格随面积变化未必是一条直线，但仍可使用线性参数模型。选择 $\phi(\mathbf{x})$ 后，所有正规方程与求解方法都保持不变，改变的是设计矩阵各列的含义。例如一维多项式使用 $1, x, \dots, x^q$ ，径向基使用 $\exp(-(x - c_j)^2/(2s^2))$ ，其中中心 c_j 和尺度 $s > 0$ 预先给定或在训练过程中选择。

样条用分段多项式描述局部变化，并约束分段之间如何连接。带结点 $\xi_1, \dots, \xi_K$ 的三次样条可用 $1, x, x^2, x^3$ 及 $(x - \xi_k)_+^3$ 展开，其中 $(a)_+ = \max(a, 0)$ ；只保留截断三次项会遗漏全局多项式部分。基函数越多，表达越灵活，也越可能出现高方差与病态设计。核方法可以隐式计算特征内积，但采用固定核并不等于从数据中自动学习全部特征表示⁵。

2.1.1.5 支持异常值鲁棒性（Huber 回归与 M-估计）

平方损失把十倍残差变成一百倍损失，少量错误记录因此可能主导拟合。**Huber 损失** (Huber loss) 在小残差处保持二次形状，在大残差处改为线性增长，从而限制残差方向的导数。它来自稳健位置估计的研究，也可用于回归目标⁶。

$$\rho_\delta(r) = \begin{cases} r^2/2, & |r| \leq \delta, \\ \delta|r| - \delta^2/2, & |r| > \delta, \end{cases} \quad \delta > 0. \quad (2.6)$$

对 $r_i = y_i - \phi(\mathbf{x}_i)^\top \mathbf{w}$ 最小化 $\sum_i \rho_\delta(r_i)$ ，估计方程为 $\sum_i \phi(\mathbf{x}_i) \psi_\delta(r_i) = \mathbf{0}$ ，其中 $\psi_\delta(r) = \max(-\delta, \min(r, \delta))$ 。令 $a_i = \min(1, \delta/|r_i|)$ ，在 $r_i = 0$ 时取 $a_i = 1$ ，便可交替计算残差权重与加权最小二乘；应检查目标和估计方程的收敛。阈值 δ 具有响应单位，常结合稳健尺度估计选择，不能把“某个倍数的中位绝对偏差”不经校准地当成普适常数。

将一般残差函数 ρ 代入 $\min_{\mathbf{w}} \sum_i \rho(r_i)$ ，得到**M-估计** (M-estimation)，即通过经验准则定义估计量。Huber 准则凸且连续可微；Tukey 双权、Cauchy 等准则则可能非凸，求解与统计性质须分别分析。有界的 ψ_δ 仅限制响应残差的影响，没有限制特征 $\phi(\mathbf{x}_i)$ 的大小，因此不能自动抵御远离其他输入的高杠杆点。偏斜条件分布下，Huber 总体目标的最优中心也未必等于条件均值。

2.1.1.6 小结

OLS 把平方损失、线性参数表示与矩阵投影连接起来。求解只依赖给定数据；无偏性、最优协方差和渐近分布分别需要额外假设。特征数接近样本数不自动导致解不唯一，唯一性由列秩决定；训练拟合值唯一也不保证不同参数解在新输入上的预测一致。共线性与高维问题促使我们控制参数规模，异常响应和非均值目标则需要重新选择损失，这两类修改将在后续小节分别展开。

⁵ T. Hastie, R. Tibshirani, J. Friedman, *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*, Springer, 2009, 2nd ed.

⁶ P. J. Huber, *Robust Estimation of a Location Parameter* In *The Annals of Mathematical Statistics*, 1964, vol. 35, no. 1, pp. 73–101

2.1.2 正则化线性回归

面积与套内面积高度相关时，许多系数组合能产生近似相同的训练预测，数据却难以分辨它们。**正则化** (regularization) 在拟合准则中加入参数约束或惩罚，限制这些缺少数据支持的变化。它可以降低估计方差，也会引入偏差；是否改善未来预测取决于真实结构、正则强度和测试分布。

2.1.2.1 模型结构

本小节将截距 b 与斜率 $\mathbf{w} \in \mathbb{R}^d$ 分开。平方损失下，固定斜率的最优截距为 $b = \bar{y} - \bar{\mathbf{x}}^\top \mathbf{w}$ ，所以可先用训练均值中心化特征与响应，只优化斜率，再恢复截距。以下 $\mathbf{X}, \mathbf{y}$ 均指中心化后的量，截距不受惩罚；需要标准化时，尺度也只能从训练集估计。

四种常见方法都在 $\|\mathbf{y} - \mathbf{X}\mathbf{w}\|_2^2/(2n)$ 之外增加凸惩罚。**岭回归** (ridge regression) 使用 $\lambda\|\mathbf{w}\|_2^2/2$ 抑制参数幅度，收缩数据约束较弱的方向。Hoerl 与 Kennard 在 1970 年的论文中系统研究了非正交设计下的有偏估计：当共线性使 OLS 方差过大时，容许一定偏差可能换来较小的均方误差⁷。

Lasso (least absolute shrinkage and selection operator) 使用 $\lambda\|\mathbf{w}\|_1$ 。绝对值惩罚在零点有尖点，使部分坐标即使受到损失项的非零斜率推动，也仍可在零点取得最优值；下面会用左右导数说明这一点。Tibshirani 在 1996 年提出这一方法，将连续收缩与变量选择放进同一个优化问题；与岭的差别因而不只是惩罚曲线的形状，还在于能否直接得到零系数⁸。

弹性网 (elastic net) 使用 $\lambda_1\|\mathbf{w}\|_1 + \lambda_2\|\mathbf{w}\|_2^2/2$ ，结合坐标稀疏与二次收缩；常写作 $\lambda_1 = \lambda\alpha, \lambda_2 = \lambda(1-\alpha)$ ，其中 $0 \leq \alpha \leq 1$ 。Zou 与 Hastie 在 2005 年研究了这种结合，以改善高相关特征下的选择与估计。这里采用直接混合惩罚的形式；原始文献还讨论了对系数重标定以修正过度收缩的版本⁹。

组 Lasso (group Lasso) 使用 $\lambda \sum_{g=1}^G \omega_g \|\mathbf{w}_{A_g}\|_2$ ，其中 $A_1, \dots, A_G$ 是不重叠的坐标组， $\omega_g > 0$ 为组权重，常取 $\sqrt{|A_g|}$ 。Yuan 与 Lin 在 2006 年将选择单位扩展到成组变量，例如一个分类特征展开的多个指示变量。该惩罚允许一整组变成零向量；被保留组中的各个坐标不必都非零¹⁰。

表2.1将四种方法放在相同的平方损失下比较。选择方法时，需要区分“系数整体变小”“某个坐标变零”和“某组变量一起变零”；这三种要求对应不同的结构假设。

图2.2进一步用二维约束说明差别。对给定约束半径，从无约束最优点向外扩张等损失线，第一次接触可行域的位置就是约束最优解。一范数球在坐标轴上有尖点，因此接触点可能恰好有零坐标；二范数球的边界光滑，通常只连续收缩系数。这个几何图解释了稀疏解为何可能出现，严格判断仍应回到最优性条件。

⁷ A. E. Hoerl, R. W. Kennard, *Ridge Regression: Biased Estimation for Nonorthogonal Problems* In *Technometrics*, 1970, vol. 12, no. 1, pp. 55–67

⁸ R. Tibshirani, *Regression Shrinkage and Selection via the Lasso* In *Journal of the Royal Statistical Society: Series B (Methodological)*, 1996, vol. 58, no. 1, pp. 267–288

⁹ H. Zou, T. Hastie, *Regularization and Variable Selection via the Elastic Net* In *Journal of the Royal Statistical Society: Series B (Statistical Methodology)*, 2005, vol. 67, no. 2, pp. 301–320

¹⁰ M. Yuan, Y. Lin, *Model Selection and Estimation in Regression with Grouped Variables* In *Journal of the Royal Statistical Society: Series B (Statistical Methodology)*, 2006, vol. 68, no. 1, pp. 49–67

方法	惩罚项	稀疏形式	相关特征与解	适用考虑
岭回归	$\lambda \ \mathbf{w}\ _2^2/2$	通常不产生零系数	分摊相关特征贡献; $\lambda > 0$ 时解唯一	多个弱效应、共线性; 重点在稳定预测
Lasso	$\lambda \ \mathbf{w}\ _1$	单坐标稀疏	可能在相关变量间选择; 解未必唯一	少数变量有效; 需检查选择的稳定性
弹性网	$\lambda_1 \ \mathbf{w}\ _1 + \lambda_2 \ \mathbf{w}\ _2^2/2$	$\lambda_1 > 0$ 时可坐标稀疏	二次项促进相近特征的系数接近; $\lambda_2 > 0$ 时解唯一	同时需要变量选择与相关特征的稳定估计
组 Lasso	$\lambda \sum_g \omega_g \ \mathbf{w}_{A_g}\ _2$	整组稀疏; 组内未必稀疏	组须预先给定; 解未必唯一	指示变量、基函数等具有已知分组的特征

表 2.1 正则化线性回归的比较。共同数据项为 $\|\mathbf{y} - \mathbf{X}\mathbf{w}\|_2^2/(2n)$, 截距不受惩罚; 组 Lasso 采用不重叠分组。稀疏性表示惩罚允许出现的结构, 并不保证任意数据和正则强度都产生零系数。特征尺度与超参数仍须在训练集内确定。




图 2.2 岭与 Lasso 的约束几何。构造损失为 $J(\mathbf{w}) = \|\mathbf{w} - (1.8, 0.6)^T\|_2^2/2$, 虚线为等损失线, 浅色区域为可行域, 空心点为 OLS 解, 实心点为约束最优解。左图解为 $(1.8, 0.6)^T/\sqrt{3.6}$, 右图解为 $(1, 0)^T$ 。两图都取单位约束半径以比较形状, 不表示相同的惩罚强度; Lasso 也并非总在尖点取到最优解。

岭惩罚并不把所有原始坐标按同一比例缩小, 下面的谱分解会给出一般设计下的收缩方向。惩罚的概率解释同样依赖归一化: 高斯似然下, 高斯先验对应二次惩罚, 各系数独立的拉普拉斯先验 (Laplace prior) 对应一范数惩罚, 但先验尺度与 λ 的对应关系还包含 n 和噪声方差。

2.1.2.2 参数学习

岭目标的梯度为零给出

$$\hat{\mathbf{w}}_\lambda = (\mathbf{X}^T \mathbf{X} + n\lambda \mathbf{I})^{-1} \mathbf{X}^T \mathbf{y}, \quad \lambda > 0. \quad (2.7)$$

任意非零 $\mathbf{v}$ 满足 $\mathbf{v}^\top(\mathbf{X}^\top\mathbf{X} + n\lambda\mathbf{I})\mathbf{v} = \|\mathbf{X}\mathbf{v}\|_2^2 + n\lambda\|\mathbf{v}\|_2^2 > 0$, 所以即使设计秩亏, 斜率解也唯一。若 $\gamma_{\max}, \gamma_{\min}$ 是 $\mathbf{X}^\top\mathbf{X}$ 的极端特征值, 正则化后该矩阵的条件数为 $(\gamma_{\max} + n\lambda)/(\gamma_{\min} + n\lambda)$; 比较对象是正规方程矩阵, 而非 $\mathbf{X}$ 本身的条件数。

取 $\mathbf{X} = \mathbf{U}_r\mathbf{D}_r\mathbf{V}_r^\top$, 正奇异值为 s_j , 则

$$\mathbf{X}\hat{\mathbf{w}}_\lambda = \sum_{j=1}^r \frac{s_j^2}{s_j^2 + n\lambda} \mathbf{u}_j \mathbf{u}_j^\top \mathbf{y}. \quad (2.8)$$

OLS 保留列空间中的全部投影, 岭回归则按 $s_j^2/(s_j^2 + n\lambda)$ 保留各方向, 小奇异值方向受到更强收缩。这是稳定性改善的来源, 也说明惩罚会同时压低这些方向上的真实信号。

Lasso 的目标记为 $F(\mathbf{w})$ 。由于 $\lambda > 0$ 时 $F(\mathbf{w}) \geq \lambda\|\mathbf{w}\|_1$, 连续目标至少取得一个最小值; 参数解未必唯一。要理解零系数为何可能最优, 可以先固定其他坐标。令 $\mathbf{r}_{-j} = \mathbf{y} - \sum_{k \neq j} \mathbf{X}_{:,k} w_k$, $a_j = \|\mathbf{X}_{:,j}\|_2^2/n$, $c_j = \mathbf{X}_{:,j}^\top \mathbf{r}_{-j}/n$, 略去常数后的单坐标目标为

$$q_j(w_j) = \frac{a_j}{2} w_j^2 - c_j w_j + \lambda |w_j|.$$

在零点左侧, 绝对值项的斜率为 $-\lambda$; 右侧则为 λ 。因此零点的左右导数分别为

$$q'_{j,-}(0) = -c_j - \lambda, \quad q'_{j,+}(0) = -c_j + \lambda.$$

这个目标是凸函数, 零点最优恰好要求左导数不大于零、右导数不小于零, 即 $|c_j| \leq \lambda$ 。此时无论向哪一侧离开零点, 目标都不会降低; 损失项在零点的导数 $-c_j$ 却不必为零。

为了统一写出光滑点与尖点的条件, 引入**次梯度** (subgradient)。对一维凸函数 f , 若斜率 s 满足 $f(v) \geq f(u) + s(v - u)$ 对所有 v 成立, 它就是 f 在 u 处的一个次梯度: 经过该点、斜率为 s 的直线始终位于函数图像下方。所有这样的斜率组成次梯度集合 $\partial f(u)$; 可导时集合只有导数一个元素, 而 $|u|$ 在零点允许 $[-1, 1]$ 中的全部斜率。凸函数的最优性因而可统一表为 $0 \in \partial f(u)$ 。对 Lasso, 损失梯度加上惩罚次梯度为零, 得到充要最优性条件

$$\frac{\mathbf{X}^\top(\mathbf{y} - \mathbf{X}\hat{\mathbf{w}})}{n} = \lambda \mathbf{z}, \quad z_j \in \begin{cases} \{\text{sign}(\hat{w}_j)\}, & \hat{w}_j \neq 0, \\ [-1, 1], & \hat{w}_j = 0. \end{cases} \quad (2.9)$$

其中非零坐标对应的绝对值导数为符号函数, 零坐标则允许整个区间来抵消损失梯度。沿用上述 a_j, c_j , 在正、负半轴求导, 并在零点检验 $|c_j| \leq \lambda$,

得到坐标更新

$$w_j \leftarrow \frac{s_\lambda(c_j)}{a_j}, \quad s_\lambda(c) = \text{sign}(c)(|c| - \lambda)_+. \quad (2.10)$$

这里 $a_j > 0$, 零列直接取零系数。**软阈值** (soft thresholding) 把阈值内的量置零, 将其余量向零移动 λ 。例如正交标准化设计下, OLS 系数 (0.12, 1.40) 在 $\lambda = 0.20$ 时变为 (0, 1.20); 相关设计则需反复更新部分残差, 不能直接阈值化 OLS 系数。循环坐标下降可用式(2.9)的违反程度作为停止依据。

弹性网的坐标更新为 $s_{\lambda_1}(c_j)/(a_j + \lambda_2)$ 。组惩罚则可用近端梯度: 先令 $\mathbf{v} = \mathbf{w} - t\mathbf{X}^\top(\mathbf{X}\mathbf{w} - \mathbf{y})/n$, 再逐组计算

$$\mathbf{w}_{A_g}^+ = \begin{cases} \mathbf{0}, & \|\mathbf{v}_{A_g}\|_2 \leq t\lambda\omega_g, \\ \left(1 - \frac{t\lambda\omega_g}{\|\mathbf{v}_{A_g}\|_2}\right)\mathbf{v}_{A_g}, & \text{其他情形.} \end{cases} \quad (2.11)$$

该式求解的是 $\min_{\mathbf{u}} \|\mathbf{u} - \mathbf{v}_{A_g}\|_2^2/2 + t\lambda\omega_g\|\mathbf{u}\|_2$: 固定 $\|\mathbf{u}\|_2$ 时, 同向选择使平方距离最小, 剩下的一维非负半轴问题给出径向阈值。它是近端子问题的闭式解, 不能不加条件地当作任意设计下的精确块坐标解。对非零设计, 取 $0 < t \leq 1/\|\mathbf{X}^\top\mathbf{X}/n\|_2$ 可保证凸近端梯度法的目标收敛性质。

沿 λ 网格使用前一个解热启动, 可以减少重复计算。LARS 的 Lasso 修正版利用分段线性路径求解一范数惩罚问题, 但这一性质不直接推广到一般 Group Lasso。超参数通常由交叉验证选择; 中心化、标准化与变量选择都必须在每个训练折内完成。不同软件对平方损失和惩罚的系数约定不同, 不能只按参数名复制同一数值¹¹。

2.1.2.3 理论分析

惩罚项一方面改变固定训练设计上的优化问题, 另一方面改变估计量的偏差、方差和支持恢复。下面先给出确定性的全局最优性, 再条件于固定设计比较参数均方误差, 并在附加噪声分布下讨论符号恢复的高概率事件。参数收缩或支持恢复仍不能推出任意测试分布上的预测优势, 更不能推出因果效应。

收敛性分析 凸性保证满足最优性条件的点是全局最优点, 但迭代算法仍需合适的步长。岭回归在 $\lambda > 0$ 时具有正定 Hessian, 梯度下降可按前述谱条件选择步长; Lasso 与组 Lasso 的近端更新则需同时处理光滑损失和非光滑惩罚。目标值收敛与参数解唯一是不同性质: 岭与含正二次惩罚的弹性网有唯一斜率解, Lasso 的唯一性还取决于设计和活跃坐标。

¹¹ T. Hastie, R. Tibshirani, J. Friedman, *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*, Springer, 2009, 2nd ed.

泛化分析 经验目标达到最小，并不保证未来预测误差也最小。正则化通过偏差与方差的变化影响统计误差。岭回归的一个精确结论是：在固定设计与真参数下，足够小的正收缩可以降低参数均方差。




图 2.3 模型复杂度变化时的偏差-方差-噪声分解示意。柱高是教学构造的相对量，不来自实验：复杂度增加时偏差平方下降、估计方差上升，不可约噪声保持不变。总误差由三部分共同决定，因此“模型更复杂”与“误差更小”都不是无条件结论。

定理 2.3 小幅岭收缩的参数均方误差 设 $\mathbf{y} = \mathbf{X}\mathbf{w}_* + \varepsilon$ ，固定设计 $\mathbf{X}$ 列满秩，参数维数至少为 1，噪声均值为零、协方差为 $\sigma^2 \mathbf{I}$ ，且 $\sigma^2 > 0$ 。则存在 $\lambda_0 > 0$ ，使所有 $0 < \lambda < \lambda_0$ 的岭估计参数均方误差严格小于 OLS。

证明. 令 $a = n\lambda$ ，将 $\mathbf{X}^\top \mathbf{X}$ 正交对角化，特征值为 $\gamma_j > 0$ ，真参数在相应方向上的坐标为 θ_j 。岭估计在第 j 个方向上的偏差为 $-a\theta_j/(\gamma_j + a)$ ，方差为 $\sigma^2\gamma_j/(\gamma_j + a)^2$ 。正交变换保持欧氏范数，故参数均方误差为

$$M(a) = \sum_j \frac{a^2\theta_j^2 + \sigma^2\gamma_j}{(\gamma_j + a)^2}.$$

函数在 $a = 0$ 附近可微，且 $M'(0) = -2\sigma^2 \sum_j \gamma_j^{-2} < 0$ 。导数定义保证存在 $a_0 > 0$ ，使所有 $0 < a < a_0$ 满足 $M(a) < M(0)$ 。取 $\lambda_0 = a_0/n$ 即可。 ■

中心化响应会使噪声协方差变成 $\sigma^2(\mathbf{I} - \mathbf{1}\mathbf{1}^\top/n)$ ，但中心化设计满足 $\mathbf{X}^\top \mathbf{1} = \mathbf{0}$ ，所以斜率方向上的上述计算仍成立。定理没有给出不依赖未知真参数的最优 λ ，也不意味着任意收缩都改善任意测试分布的预测风险。

Lasso 能否认出真实非零变量，则是更强的问题。仅有稀疏性还不够：

无关变量若可由相关变量近似替代, 就难以判定贡献应归给谁。**不可表示条件** (irrepresentable condition) 限制这种替代关系; 符号恢复还需要噪声和最小信号条件¹²。

¹² P. Zhao, B. Yu, *On Model Selection Consistency of Lasso* In Journal of Machine Learning Research, 2006, vol. 7, no. 90, pp. 2541–2563

定理 2.4 Lasso 的确定性符号恢复充分条件 设 $\mathbf{y} = \mathbf{X}\mathbf{w}_\star + \boldsymbol{\varepsilon}$, $A = \{j : w_{\star,j} \neq 0\}$ 非空, $\mathbf{X}_A = \mathbf{X}_{:,A}$ 列满秩。记

$$\mathbf{G} = \mathbf{X}^\top \mathbf{X} / n, \quad \mathbf{s} = \text{sign}(\mathbf{w}_{\star,A}), \quad \mathbf{P}_A = \mathbf{X}_A (\mathbf{X}_A^\top \mathbf{X}_A)^{-1} \mathbf{X}_A^\top,$$

以及 $\mathbf{q} = \mathbf{G}_{A^c,A}^{-1} \mathbf{X}_A^\top \boldsymbol{\varepsilon} / n$ 、 $\mathbf{b} = \mathbf{G}_{A,A}^{-1} \mathbf{s}$ 。若 $\lambda > 0$, 且存在 $0 < \eta \leq 1$ 使

$$\|\mathbf{G}_{A^c,A} \mathbf{G}_{A,A}^{-1} \mathbf{s}\|_\infty \leq 1 - \eta, \quad (2.12)$$

$$\left\| \mathbf{X}_{A^c}^\top (\mathbf{I} - \mathbf{P}_A) \boldsymbol{\varepsilon} / n \right\|_\infty \leq \lambda \eta / 2, \quad (2.13)$$

$$\min_{j \in A} |w_{\star,j}| > \|\mathbf{q}\|_\infty + \lambda \|\mathbf{b}\|_\infty, \quad (2.14)$$

则 Lasso 解唯一, 且 $\text{sign}(\hat{\mathbf{w}}) = \text{sign}(\mathbf{w}_\star)$ 。 A^c 为空时, 前两个条件为空条件。

证明. 构造 $\tilde{\mathbf{w}}_{A^c} = \mathbf{0}$ 、 $\tilde{\mathbf{w}}_A = \mathbf{w}_{\star,A} + \mathbf{q} - \lambda \mathbf{b}$ 。最小信号条件保证每个活跃坐标的扰动小于其原绝对值, 因此符号仍为 $\mathbf{s}$ 。残差满足

$$\mathbf{r} = \mathbf{y} - \mathbf{X}\tilde{\mathbf{w}} = (\mathbf{I} - \mathbf{P}_A) \boldsymbol{\varepsilon} + \lambda \mathbf{X}_A \mathbf{G}_{A,A}^{-1} \mathbf{s}.$$

令 $\tilde{\mathbf{z}} = \mathbf{X}^\top \mathbf{r} / (n\lambda)$, 则 $\tilde{\mathbf{z}}_A = \mathbf{s}$, 且

$$\tilde{\mathbf{z}}_{A^c} = \mathbf{G}_{A^c,A} \mathbf{G}_{A,A}^{-1} \mathbf{s} + \frac{\mathbf{X}_{A^c}^\top (\mathbf{I} - \mathbf{P}_A) \boldsymbol{\varepsilon}}{n\lambda}.$$

前两个条件给出 $\|\tilde{\mathbf{z}}_{A^c}\|_\infty \leq 1 - \eta/2 < 1$ 。因此 $\tilde{\mathbf{z}}$ 是合法次梯度, 式(2.9)成立, 候选解最优。

对任意扰动 $\mathbf{h}$, 精确展开目标差并代入平稳条件, 得到

$$\begin{aligned} F(\tilde{\mathbf{w}} + \mathbf{h}) - F(\tilde{\mathbf{w}}) &= \frac{\|\mathbf{X}\mathbf{h}\|_2^2}{2n} \\ &\quad + \lambda (\|\tilde{\mathbf{w}} + \mathbf{h}\|_1 - \|\tilde{\mathbf{w}}\|_1 - \tilde{\mathbf{z}}^\top \mathbf{h}). \end{aligned}$$

活跃坐标的括号贡献由次梯度不等式非负; 非活跃坐标的贡献至少为 $(\eta/2)|h_j|$ 。若扰动后仍最优, 必有 $\mathbf{h}_{A^c} = \mathbf{0}$ 与 $\mathbf{X}\mathbf{h} = \mathbf{0}$, 故 $\mathbf{X}_A \mathbf{h}_A = \mathbf{0}$ 。活跃设计满列秩进一步推出 $\mathbf{h}_A = \mathbf{0}$, 唯一性得证。 ■

这个命题直接约束一份数据中的噪声向量, 不需要高斯假设。要得到高概率恢复, 还须对这些约束的概率作估计。例如在固定设计、独立高斯噪

声且 $\|\mathbf{X}_{:,j}\|_2 \leq \sqrt{n}$ 下, 并合界给出

$$\mathbb{P}\left(\|\mathbf{X}_{A^c}^\top (\mathbf{I} - \mathbf{P}_A) \boldsymbol{\varepsilon} / n\|_\infty > \lambda \eta / 2\right) \leq 2|A^c| \exp\left(-\frac{n\lambda^2 \eta^2}{8\sigma^2}\right).$$

活跃坐标上的 $\mathbf{q}$ 还须另外控制, 不能只凭这个尾界完成恢复结论。预测准确、支持集恢复和因果解释也不同: 两个相关特征的替换可能几乎不影响预测, 却改变所选变量; 非零预测系数本身不能证明干预效应。

2.1.2.4 支持相关特征的分组稳定 (Elastic Net)

弹性网中的 $\lambda_2 > 0$ 使整个目标严格凸, 即使设计秩亏也有唯一参数解。若两列完全相同, 交换相应系数不改变目标, 唯一性便要求两个系数相等。二次惩罚由此排除了完全相同特征之间任意分摊系数的歧义。

对两个非零且同号的系数, 把各自的最优性条件相减, 可得

$$\lambda_2 |\hat{w}_j - \hat{w}_k| \leq \frac{\|\mathbf{X}_{:,j} - \mathbf{X}_{:,k}\|_2 \|\mathbf{y} - \mathbf{X} \hat{\mathbf{w}}\|_2}{n}.$$

因此在相同尺度下, 两列越接近, 其同号估计越接近。这个界以非零同号为条件, 不保证任何相关变量组都被选中。实际选择 α, λ 时, 仍应根据预测或变量选择的目标验证稳定性。

2.1.2.5 支持结构化稀疏 (Group Lasso)

一个类别变量的多个指示变量, 或一个连续变量的整组样条基, 常需要作为整体评价。组 Lasso 把这样的先验分组写进惩罚; 在非零组上, 惩罚的梯度方向是 $\mathbf{w}_{A_g} / \|\mathbf{w}_{A_g}\|_2$, 零组处的次梯度则是单位球。组内残差相关向量未超过 $\lambda \omega_g$ 时, 整组可以保持为零。

权重 $\sqrt{|A_g|}$ 能补偿组大小的一部分影响, 但并不消除组内相关性或量纲差异。若还希望在保留组内继续选择坐标, 可使用**稀疏组 Lasso** (sparse group Lasso), 即在组惩罚之外再加 $\lambda_1 \|\mathbf{w}\|_1$ 。这同时约束组与坐标两个层次; 选择一致性仍需要适当设计、信号强度及正则化条件, 不能仅由“真实参数有组结构”推出。

2.1.2.6 小结

岭、Lasso、弹性网与组 Lasso 分别强调连续收缩、坐标稀疏、相关系数稳定性和组稀疏。它们共享凸损失加惩罚的框架, 但并不共享所有路径算法或恢复定理。进一步的相关工作还包括自适应加权的 Adaptive Lasso、惩罚相邻系数差的 Fused Lasso, 以及对大系数减弱收缩的 SCAD 和 MCP 非凸惩罚。“Oracle 性质”指在特定渐近条件下达到仿佛已知真支持集的估计行为, 不是这些方法在任意数据上的保证; 非凸惩罚还带来局部最优的

计算问题¹³。

处理共线性的另一条路线是先降维再回归。**主成分回归** (principal component regression, PCR) 保留若干主成分, 在这些正交方向上拟合, 等价于对选中方向完全保留、对其余方向硬截断。第5.1.1节从无监督表示的角度推导主成分分析 (PCA): PCA 与 PCR 共享由输入方差确定的主成分基, 但 PCA 按方差保留与重构误差评价表示, PCR 还要用响应检验这些成分是否有利于预测。与式(2.8)的连续收缩相比, PCR 的取舍更直接, 但输入方差小不意味着对响应不重要。**偏最小二乘回归** (partial least squares regression, PLS) 在构造成分时同时利用输入与响应的关系, 因而属于监督降维; 它有不同的具体算法, 不能笼统理解为收缩因子必在 0 和 1 之间的岭回归。成分数同样需要在训练折内选择。

¹³ T. Hastie, R. Tibshirani, J. Friedman, *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*, Springer, 2009, 2nd ed.

2.1.3 分位数回归 (Quantile Regression)

预算制定者关心的是实际支出超过预算的概率, 单个条件均值无法回答这个问题。**分位数回归** (quantile regression) 用非对称残差损失估计给定输入后的指定分位数; 例如 0.9 分位数提供一个使响应至少有 90% 概率不超过它的条件阈值。Koenker 与 Bassett 在 1978 年系统提出回归分位数, 将回归目标从条件均值扩展到条件分布的不同位置。这一区分源于决策目标, 无需先假定误差对称或同方差¹⁴。

¹⁴ R. Koenker, G. Bassett Jr., *Regression Quantiles In Econometrica*, 1978, vol. 46, no. 1, pp. 33–50

2.1.3.1 模型结构

给定 $0 < \tau < 1$, 定义**分位数损失** (pinball loss)

$$\rho_{\tau}(r) = \begin{cases} \tau r, & r \geq 0, \\ (1 - \tau)(-r), & r < 0. \end{cases} \quad (2.15)$$

残差仍取 $r = y - \hat{y}$, 所以较大的 τ 更重地惩罚低估。线性分位数回归最小化 $\sum_i \rho_{\tau}(y_i - \phi(\mathbf{x}_i)^{\top} \mathbf{w})$ 。这一形式为何对应分位数, 可以直接证明。

定理 2.5 分位数损失的总体最优解 若 $\mathbb{E}|Y| < \infty$, 分布函数为 F_Y , 则 $Q(a) = \mathbb{E}[\rho_{\tau}(Y - a)]$ 的全部最小化点恰好满足

$$F_Y(a-) \leq \tau \leq F_Y(a), \quad F_Y(a-) = \mathbb{P}(Y < a).$$

证明. 对固定 Y , 损失关于 a 凸, 斜率绝对值不超过 1。有界收敛允许单侧差商与期望交换。当 $Y < a$ 时斜率为 $1 - \tau$, 当 $Y > a$ 时为 $-\tau$; 在 $Y = a$ 处左、右导数分别取这两个值中的 $-\tau$ 与 $1 - \tau$ 。故

$$Q'_-(a) = F_Y(a-) - \tau, \quad Q'_+(a) = F_Y(a) - \tau.$$

凸函数在 a 处最小当且仅当 $Q'_-(a) \leq 0 \leq Q'_+(a)$ 。分布函数从 0 增长到 1，保证这样的点存在。 ■

将分布换成给定输入的条件分布，便得到条件分位数；换成经验分布，便得到样本分位数。 $\tau = 1/2$ 时损失为 $|r|/2$ ，对应中位数。分布存在原子或平台时最优解可能不唯一，因此不能一律写成 $F_Y(a) = \tau$ 。在线性模型受到限制时，只有正确指定等条件下才能精确表示真实条件分位数，一般得到该函数类中的最佳损失逼近。

2.1.3.2 参数学习

引入非负正、负残差 $\mathbf{u}, \mathbf{v} \in \mathbb{R}^n$ ，可将目标写成线性规划

$$\begin{aligned} \min_{\mathbf{w}, \mathbf{u}, \mathbf{v}} \quad & \tau \mathbf{1}^\top \mathbf{u} + (1 - \tau) \mathbf{1}^\top \mathbf{v}, \\ \text{满足} \quad & \mathbf{y} - \mathbf{X}\mathbf{w} = \mathbf{u} - \mathbf{v}, \quad \mathbf{u} \geq \mathbf{0}, \mathbf{v} \geq \mathbf{0}. \end{aligned} \quad (2.16)$$

若某个 u_i, v_i 同时为正，同时减小二者保持约束不变且严格降低目标，因此最优时二者不会同时为正，线性规划与原损失等价。可采用单纯形法、内点法或适合数据规模的非光滑凸优化算法；非光滑并不意味着只能使用线性规划。

高维时可在平均分位数损失之外增加 $\lambda \|\mathbf{w}\|_1$ ，通过把系数也拆为正负部分继续写成线性规划。多个 τ 可以分别拟合，也可以联合加入顺序约束；超参数评价应使用对应的分位数损失，而不是仅凭平方误差判断。

2.1.3.3 小结

分位数回归把预测从条件均值扩展到分布中的指定位置，多个分位数有助于描述分布形状，但有限网格不等于完整条件分布。独立拟合可能出现较高分位数反而更低的分位数交叉，联合约束需说明在哪些输入上生效。线性尾部损失降低了大残差的边际作用，却不自动抵御高杠杆点；极端分位数仍需要足够尾部数据。预测区间由分位数组成后，其覆盖率也需要单独评价。

2.1.4 支持向量回归 (SVR)

另一种误差评价允许小偏差不计损失，只惩罚超出容忍范围的部分。**支持向量回归** (support vector regression, SVR) 将这种损失与二次正则化结合，得到一个由训练样本加权表示的预测函数。部分样本的权重可以为零，核化以后只需保留非零权重对应的样本来计算预测。这是样本展开的稀疏性，与 Lasso 选择输入变量的稀疏性不同¹⁵。

¹⁵ A. J. Smola, B. Schölkopf, *A Tutorial on Support Vector Regression In Statistics and Computing*, 2004, vol. 14, no. 3, pp. 199–222

2.1.4.1 模型结构

设 $\epsilon \geq 0$ ，定义 ϵ **不敏感损失** (ϵ -insensitive loss) 为 $L_\epsilon(r) = (|r| - \epsilon)_+$ 。它把 $\pm\epsilon$ 之间的残差视为可容忍误差，超出部分线性计入损失。线性 SVR 单独保留不受惩罚的截距 b ，目标为

$$\min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|_2^2 + C \sum_{i=1}^n L_\epsilon(y_i - \mathbf{w}^\top \mathbf{x}_i - b), \quad C > 0. \quad (2.17)$$

除以 nC ，可知它与“平均损失 $+\lambda \|\mathbf{w}\|_2^2/2$ ”在 $\lambda = 1/(nC)$ 时等价。 C 越大，训练误差在目标中的相对权重越大； ϵ 则具有响应的单位，规定不计损失的范围。

为推导对偶问题，引入 $\xi_i^+, \xi_i^- \geq 0$ ，分别表示两个方向超出容忍带的量。等价约束形式为

$$\begin{aligned} \min_{\mathbf{w}, b, \xi_i^+, \xi_i^-} \quad & \frac{1}{2} \|\mathbf{w}\|_2^2 + C \sum_i (\xi_i^+ + \xi_i^-), \\ \text{满足} \quad & y_i - \mathbf{w}^\top \mathbf{x}_i - b \leq \epsilon + \xi_i^+, \\ & \mathbf{w}^\top \mathbf{x}_i + b - y_i \leq \epsilon + \xi_i^-, \\ & \xi_i^+, \xi_i^- \geq 0, \quad i = 1, \dots, n. \end{aligned} \quad (2.18)$$

固定预测时，由 $C > 0$ 可知最优松弛量恰为超出带宽的部分。 $\epsilon = 0$ 对应带二次惩罚的绝对损失回归。对固定有限数据，若 $\epsilon \geq (\max_i y_i - \min_i y_i)/2$ ，则 $\mathbf{w} = \mathbf{0}$ 和某个常数 b 已能使全部样本进入容忍带，目标取得零值。截距在此时可能不唯一。

2.1.4.2 参数学习

原问题是在可行参数中寻找最小目标值，为什么下面会出现一个最大化问题？把各不等式写成“左边不大于零”，分别乘以非负的拉格朗日乘子并加到目标中，就得到拉格朗日函数。在任一可行点，这些附加项都不大于零；固定乘子，再对全部原始变量取下确界，便得到原问题最优值的一个下界。选择乘子把这个下界尽量抬高，就是**对偶** (dual) 最大化。乘子在这里用于构造下界；若最佳下界等于原问题的最小值，就称为**强对偶** (strong duality)。

下面用凸优化条件判断这一对应何时成立。Slater 条件要求在满足等式约束的同时存在严格可行的不等式点，它在当前凸问题中用于建立强对偶；KKT 条件把原始可行性、对偶可行性、驻点条件和互补松弛放在同一组方程中，其中互补松弛要求乘子与对应约束余量的乘积为零。在凸问题满足 Slater 条件时，KKT 条件对最优性既必要又充分；分类 SVM 中的对应条件见式(3.27)。

为前两组约束引入乘子 $\alpha_i^+, \alpha_i^- \geq 0$, 为松弛量非负约束引入 $\mu_i^+, \mu_i^- \geq 0$ 。令 $r_i = y_i - \mathbf{w}^\top \mathbf{x}_i - b$, 拉格朗日函数为

$$\begin{aligned} \mathcal{L} = & \frac{1}{2} \|\mathbf{w}\|_2^2 + C \sum_i (\xi_i^+ + \xi_i^-) + \sum_i \alpha_i^+ (r_i - \epsilon - \xi_i^+) \\ & + \sum_i \alpha_i^- (-r_i - \epsilon - \xi_i^-) - \sum_i (\mu_i^+ \xi_i^+ + \mu_i^- \xi_i^-). \end{aligned}$$

分别对 $\mathbf{w}, b, \xi_i^\pm$ 求导, 得到

$$\mathbf{w} = \sum_i (\alpha_i^+ - \alpha_i^-) \mathbf{x}_i, \quad \sum_i (\alpha_i^+ - \alpha_i^-) = 0, \quad C - \alpha_i^+ - \mu_i^+ = 0.$$

最后一式给出 $0 \leq \alpha_i^\pm \leq C$ 。记 $\beta_i = \alpha_i^+ - \alpha_i^-$, 消去原始变量后, 对偶问题为

$$\begin{aligned} \max_{\alpha^+, \alpha^-} \quad & -\frac{1}{2} \sum_{i,j} \beta_i \beta_j \mathbf{x}_i^\top \mathbf{x}_j - \epsilon \sum_i (\alpha_i^+ + \alpha_i^-) + \sum_i y_i \beta_i, \\ \text{满足} \quad & \sum_i \beta_i = 0, \quad 0 \leq \alpha_i^\pm \leq C. \end{aligned} \quad (2.19)$$

原始问题凸, 选择足够大的正松弛量即可严格满足不等式, 因此满足 Slater 条件, 强对偶成立。对偶是带盒约束与一个线性等式约束的凸二次规划的最大化写法, 可通过分解算法逐步更新少量变量; 每次更新应保持等式约束, 并以最优性残差作为停止依据。

得到乘子后, 若 $0 < \alpha_i^+ < C$, 互补松弛给出 $r_i = \epsilon$, 所以 $b = y_i - \mathbf{w}^\top \mathbf{x}_i - \epsilon$; 若 $0 < \alpha_i^- < C$, 则 $b = y_i - \mathbf{w}^\top \mathbf{x}_i + \epsilon$ 。可对多个此类样本的截距估计取平均以减小数值误差。若没有内点乘子, 应根据全部 KKT 不等式求可行截距区间, 不能假设总能找到一个严格介于 0 与 C 之间的乘子。

2.1.4.3 理论分析

SVR 的对偶结构能够回答固定训练集上的凸最优性, 却不能直接回答独立新样本上的预测风险。前者可由对偶间隙和 KKT 残差作确定性判断; 后者还须给出抽样制度、函数类与响应尾部条件。因而, 支持向量较少或优化误差较小不能推出分布无关的泛化保证。

收敛性分析 SVR 的原始问题是凸优化问题, 前述强对偶与 KKT 条件给出了全局最优性的判据。数值求解时, 可以用原始可行解与对偶可行解的目标差距控制尚未消除的优化误差; 具体迭代的收敛速度仍取决于求解器、设计与核矩阵。

支持向量与残差位置的关系必须区分带内、带外和边界三个情况。边界上的约束虽然取等号, 乘子仍然可以为零。

定理 2.6 SVR 的样本系数与残差 设 $\epsilon > 0$ ，在任意一组原始与对偶最优解处记 $r_i = y_i - \mathbf{w}^\top \mathbf{x}_i - b$ 、 $\beta_i = \alpha_i^+ - \alpha_i^-$ 。则

残差位置	对偶乘子
$ r_i < \epsilon$	$\alpha_i^+ = \alpha_i^- = 0$
$r_i > \epsilon$	$\alpha_i^+ = C, \alpha_i^- = 0$
$r_i < -\epsilon$	$\alpha_i^+ = 0, \alpha_i^- = C$
$r_i = \epsilon$	$\alpha_i^+ \in [0, C], \alpha_i^- = 0$
$r_i = -\epsilon$	$\alpha_i^+ = 0, \alpha_i^- \in [0, C]$

因而 $\beta_i \neq 0$ 蕴含 $|r_i| \geq \epsilon$ ，反向蕴含在边界处不成立。

证明. 最优松弛量为 $\xi_i^+ = (r_i - \epsilon)_+$ 、 $\xi_i^- = (-r_i - \epsilon)_+$ 。KKT 互补松弛条件为

$$\alpha_i^+(\epsilon + \xi_i^+ - r_i) = 0, \quad \alpha_i^-(\epsilon + \xi_i^- + r_i) = 0, \quad (C - \alpha_i^\pm)\xi_i^\pm = 0.$$

严格带内时两个残差约束都松弛，故两个乘子均为零。若 $r_i > \epsilon$ ，则 $\xi_i^+ > 0$ 迫使 $\alpha_i^+ = C$ ，另一个残差约束严格松弛，故 $\alpha_i^- = 0$ ；负向带外同理。若 $r_i = \epsilon$ ，正向松弛量为零，其乘子仅受盒约束限制；由于 $\epsilon > 0$ ，负向残差约束严格松弛，故 $\alpha_i^- = 0$ 。另一侧边界同理。■

一个反例足以排除边界处的“当且仅当”：取单个样本、 $\mathbf{x}_1 = \mathbf{0}$ ，令 $\mathbf{w} = \mathbf{0}$ 、 $b = y_1 - \epsilon$ ，则 $r_1 = \epsilon$ ，原始目标为零；两个乘子均为零也满足对偶最优性。这个边界样本的系数为零。 $\epsilon = 0$ 时两个边界重合，零残差处两类乘子可能同时非零，必须单独处理，不能沿用上表的两行边界结论。

泛化分析 稀疏性由实际最优解决定，支持向量数并不保证随着 ϵ 严格单调下降；改变 ϵ 也会改变整条预测函数。评价泛化还需控制函数类及数据分布，例如核对角线、参数范数、截距或响应尾部。仅凭支持向量少，不能推出测试误差小。有限步数的优化误差与由有限样本造成的统计误差，也应分别评价。

2.1.4.4 支持非线性回归（核 SVR）

使用第 1.2.1.1 节的正定核 K ，把式 (2.19) 中的 $\mathbf{x}_i^\top \mathbf{x}_j$ 换为 $K(\mathbf{x}_i, \mathbf{x}_j)$ ，便得到特征空间中的同一个 SVR 对偶问题。预测为

$$f(\mathbf{x}) = \sum_{i=1}^n \beta_i K(\mathbf{x}_i, \mathbf{x}) + b. \quad (2.20)$$

核函数及其合法性见第1.2.1.2节与第1.2.1.3节。此处新增的是 ϵ 不敏感响应损失与系数约束；分类 SVM 使用的间隔损失不会因此变成回归目标。

核 SVR 沿用相同的对偶结构，但计算规模从显式特征维数转向训练样本数。核矩阵若完整保存需要 $O(n^2)$ 空间，采用缓存可以降低内存占用；训练时间还依赖求解器、精度及数据条件。预测需要约 n_{SV} 次核计算，其中 n_{SV} 为非零展开系数的样本数。线性核则可预先合并 $\mathbf{w}$ ，使预测成本恢复为 $O(d)$ 。

2.1.4.5 小结

SVR 在固定容忍带下折中残差代价与函数范数，核化使这种折中作用于非线性函数类。它不直接针对任意 τ 的条件分位数，也不由损失形式自动产生完整预测分布。 ν -SVR 通过另一个参数控制与误差比例、支持向量比例有关的约束，具体比例结论有相应条件；最小二乘 SVR 把损失换为平方形式，与核岭回归密切相关，但是否惩罚截距必须一致后才能判断等价。核选择与 C, ϵ 调参共同影响结果，不能按一个固定样本量门槛判断方法是否适用。

2.1.5 广义线性模型 (GLM)

预测每天的交易次数时，均值必须非负；预测交易是否成功时，均值是 $[0, 1]$ 中的概率。平方损失可以用于这些响应，但无约束线性预测不自动满足取值范围，也没有规定均值与方差的关系。**广义线性模型** (generalized linear model, GLM) 把响应分布、均值和线性预测器连接起来。Nelder 与 Wedderburn 在 1972 年给出这一统一框架，使高斯、二项和 Poisson 等响应可以沿同一条似然与加权最小二乘路线处理；扩展的关键是响应分布与链接，而不只是增加多项式特征¹⁶。

2.1.5.1 模型结构

条件于输入，假设响应相互独立，密度或概率质量函数具有指数族形式

$$p(y_i | \theta_i, \varphi) = \exp \left\{ \frac{y_i \theta_i - b(\theta_i)}{a(\varphi)} + c(y_i, \varphi) \right\}, \quad a(\varphi) > 0. \quad (2.21)$$

θ_i 是自然参数， φ 是离散度参数或尺度参数；此处为便于推导，所有观测使用相同的 $a(\varphi)$ 。函数 a, b, c 的形式由选定的分布族确定，并不作为三个未知函数一起学习。例如，均值为 $\mu_i > 0$ 的 Poisson 分布可写成

$$p(y_i | \mu_i) = \frac{\mu_i^{y_i} e^{-\mu_i}}{y_i!} = \exp\{y_i \log \mu_i - \mu_i - \log(y_i!)\}.$$

¹⁶ J. A. Nelder, R. W. M. Wedderburn, *Generalized Linear Models* In Journal of the Royal Statistical Society: Series A (General), 1972, vol. 135, no. 3, pp. 370–384

逐项对照式(2.21), 可得 $\theta_i = \log \mu_i$ 、 $b(\theta_i) = e^{\theta_i}$ 、 $a(\varphi) = 1$ 、 $c(y_i, \varphi) = -\log(y_i!)$ 。这里没有额外待估的离散度参数, 自然参数也不是均值本身。

一般情形下, 假定支持集不随 θ_i 改变, 并允许交换积分 (离散情形为求和) 与微分。密度积分为 1, 对 θ_i 求导得到 $\mathbb{E}[Y_i - b'(\theta_i)] = 0$; 再求一次导数得到

$$\mathbb{E}\left[\frac{(Y_i - b'(\theta_i))^2}{a(\varphi)^2} - \frac{b''(\theta_i)}{a(\varphi)}\right] = 0.$$

因此均值与方差为

$$\mu_i = b'(\theta_i), \quad \text{Var}(Y_i | \mathbf{x}_i) = a(\varphi)b''(\theta_i) = a(\varphi)V(\mu_i). \quad (2.22)$$

函数 V 描述方差怎样随均值变化。GLM 再引入线性预测器 $\eta_i = \boldsymbol{\phi}(\mathbf{x}_i)^\top \mathbf{w}$ 与**链接函数** (link function) g , 令 $g(\mu_i) = \eta_i$ 。链接作用于条件均值, 而不是把每个观测 y_i 变换后做 OLS。若 $\eta_i = \theta_i$, 称为规范链接。

表2.2列出三种基本组合。伯努利模型的均值就是成功概率, 因此 logistic 回归既可作为概率回归理解, 也可在给定决策阈值后用于分类。第3.4.1节沿用伯努利似然、logit 链接与 IRLS 计算, 但把重点转向类别标签的概率、决策阈值与校准; 本节则借这一特例说明 GLM 中响应分布、链接和均值方差关系的共同结构。Poisson 模型采用对数链接, 使 $\mu_i = \exp(\eta_i) > 0$; 响应是整数, 条件均值却不必为整数。

响应模型	$b(\theta)$	规范链接 $g(\mu)$	$V(\mu)$
高斯	$\theta^2/2$	μ	1
伯努利	$\log(1 + e^\theta)$	$\log \frac{\mu}{1-\mu}$	$\mu(1-\mu)$
Poisson	e^θ	$\log \mu$	μ

表 2.2 GLM 的三个常用特例。高斯模型的 $a(\varphi) = \sigma^2$, 后两者的 $a(\varphi) = 1$ 。链接保证均值范围, 分布假设进一步规定条件方差。

二项分布可处理已知试验次数下的成功数; Gamma 模型可处理正连续响应。链接选择并不唯一, 必须同时满足自然参数域和均值域的要求。Poisson 的均值方差相等也可能与数据不符, 过度离散、零膨胀或观测相关性需要额外建模, 不能靠对数链接本身解决。

2.1.5.2 参数学习

记 $\mathbf{z}_i = \boldsymbol{\phi}(\mathbf{x}_i)$, 设计矩阵第 i 行为 $\mathbf{z}_i^\top$, 暂将 φ 视为已知。由 $d\mu_i/d\theta_i = V(\mu_i)$ 及 $d\eta_i/d\mu_i = g'(\mu_i)$, 对数似然的得分为

$$U(\mathbf{w}) = \sum_i \frac{y_i - \mu_i}{a(\varphi)V(\mu_i)g'(\mu_i)} \mathbf{z}_i. \quad (2.23)$$

在所需导数存在且 $g'(\mu_i) \neq 0$ 时, 期望负 Hessian 即 Fisher 信息 $\mathbf{X}^\top \mathbf{W} \mathbf{X}$, 其中

$$W_{i,i} = \frac{1}{a(\varphi)V(\mu_i)[g'(\mu_i)]^2}.$$

Fisher 评分 (Fisher scoring) 用这个期望曲率修正当前参数, 更新 $\mathbf{w}^+ = \mathbf{w} + (\mathbf{X}^\top \mathbf{W} \mathbf{X})^{-1} \mathbf{U}(\mathbf{w})$. 要把它写成加权最小二乘, 需要先把响应尺度上的误差换算成线性预测器尺度上的修正。在当前均值附近, 链接函数的一阶近似为 $g(\mu_i + \Delta\mu) \approx \eta_i + g'(\mu_i)\Delta\mu$; 将残差 $y_i - \mu_i$ 作为局部修正信号, 便得到**工作响应** (working response)

$$z_i^{\text{work}} = \eta_i + (y_i - \mu_i)g'(\mu_i),$$

它是本轮局部子问题的目标值, 会随当前参数改变, 并非把真实标签永久变成 $g(y_i)$ 。固定当前参数时, 这个仿射换算后的响应方差为 $a(\varphi)V(\mu_i)[g'(\mu_i)]^2$, 其倒数正是 $W_{i,i}$; 换算后方差较大的观测因而权重较小。代入可得 $\mathbf{U} = \mathbf{X}^\top \mathbf{W}(\mathbf{z}^{\text{work}} - \mathbf{X}\mathbf{w})$, 从而

$$\mathbf{w}^+ = (\mathbf{X}^\top \mathbf{W} \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{W} \mathbf{z}^{\text{work}}. \quad (2.24)$$

这就是**迭代重加权最小二乘** (iteratively reweighted least squares, IRLS): 在当前均值附近构造一个加权平方子问题。实际使用分解求解线性方程, 检查秩、参数域与似然下降情况, 必要时采用阻尼或线搜索。各观测共享的 $a(\varphi)$ 在无惩罚参数更新中可以约去, 但在信息矩阵和方差计算中不能遗漏。

规范链接下, $\theta_i = \eta_i$, 负对数似然的 Hessian 为

$$\frac{1}{a(\varphi)} \mathbf{X}^\top \text{diag}(b''(\eta_i)) \mathbf{X}.$$

它半正定, 因此目标凸; 若 $b''(\eta_i) > 0$ 且设计列满秩, 则有限参数域内严格凸。这时 Newton 法与 Fisher 评分具有相同的曲率矩阵, 但完整步长不自动保证每次都提高似然, 更不能保证有限最优解存在。

2.1.5.3 理论分析

对 GLM, 首要边界是固定样本上有限最大似然解是否存在以及数值过程能否求到它; 只有在模型正确、维数固定且样本独立同分布时, 才进一步讨论估计量的渐近分布。相应结论分别是存在性边界与依分布收敛, 不能推出有限样本预测风险, 也不能把参数区间直接当作未来响应区间。

收敛性分析 严格凸性只能保证已经存在的最优解唯一。以无惩罚 logistic 回归为例, 若存在方向 $\mathbf{v}$ 使类别标签 $t_i \in \{-1, 1\}$ 满足 $t_i \mathbf{z}_i^\top \mathbf{v} > 0$, 则负对数似然 $\sum_i \log(1 + \exp(-t_i \mathbf{z}_i^\top \mathbf{w}))$ 在 $\mathbf{w} = a\mathbf{v}$ 、 $a \rightarrow \infty$ 时趋于零, 却在每个有

限参数处严格为正。即使设计满秩，也没有有限最大似然估计。分离、近似分离和病态设计都可能使迭代参数持续增大。

泛化分析 有限样本估计量的分布可以帮助量化参数及预测的不确定性，但它与优化算法的收敛是不同问题。下面给出渐近正态性的充分条件与证明，将估计一致性和局部曲率控制明确列出；具体 GLM 还需根据分布、链接和输入矩条件验证它们。

定理 2.7 正则 GLM 估计的渐近正态性 设观测独立同分布，模型正确指定，参数维数固定，真参数 $\mathbf{w}_\star$ 位于参数域内部。单样本对数似然 $\ell_i(\mathbf{w})$ 在真参数的某凸邻域二阶连续可微，并满足

$$\mathbb{E}[\nabla \ell_i(\mathbf{w}_\star)] = \mathbf{0}, \quad \text{Cov}(\nabla \ell_i(\mathbf{w}_\star)) = \mathbf{I}_\star > 0.$$

假设有限的内部最大似然估计 $\hat{\mathbf{w}}_n$ 以趋于 1 的概率存在且一致；对 $J_n(\mathbf{w}) = -n^{-1} \sum_i \nabla^2 \ell_i(\mathbf{w})$ ，在该邻域内有一致依概率收敛 $J_n \rightarrow J$ ，其中 J 在 $\mathbf{w}_\star$ 连续且 $J(\mathbf{w}_\star) = \mathbf{I}_\star$ 。则

$$\sqrt{n}(\hat{\mathbf{w}}_n - \mathbf{w}_\star) \xrightarrow{d} \mathcal{N}(\mathbf{0}, \mathbf{I}_\star^{-1}).$$

证明. 令 $\boldsymbol{\delta}_n = \hat{\mathbf{w}}_n - \mathbf{w}_\star$ 。在估计位于上述邻域且满足得分方程的事件上，沿两点连线应用微积分基本定理，得到精确等式

$$\mathbf{0} = \sum_i \nabla \ell_i(\mathbf{w}_\star) - n \left[\int_0^1 J_n(\mathbf{w}_\star + t\boldsymbol{\delta}_n) dt \right] \boldsymbol{\delta}_n.$$

一致性、一致曲率收敛与 J 的连续性给出方括号内矩阵依概率趋于 $\mathbf{I}_\star$ ，因而以趋于 1 的概率可逆。于是

$$\sqrt{n} \boldsymbol{\delta}_n = \left[\int_0^1 J_n(\mathbf{w}_\star + t\boldsymbol{\delta}_n) dt \right]^{-1} \frac{1}{\sqrt{n}} \sum_i \nabla \ell_i(\mathbf{w}_\star).$$

独立同分布得分具有有限协方差，多元中心极限定理使右侧最后一项趋于 $\mathcal{N}(\mathbf{0}, \mathbf{I}_\star)$ ；再用 Slutsky 定理即得结论。整个事件的概率趋于 1，不改变极限分布。 ■

积分 Hessian 不能一般性地替换为某个共同中间点上的 Hessian，因为向量得分各分量的标量中值点未必相同。在 GLM 中，单观测信息为

$$\mathbf{I}_\star = \mathbb{E} \left[\frac{\mathbf{z}\mathbf{z}^\top}{a(\varphi)V(\mu_\star)[g'(\mu_\star)]^2} \right].$$

上述定理是在假定一致性的基础上推出分布极限，不以正定信息矩阵单独

代替全部正则条件。若另行限制到紧参数集，连续总体准则具有唯一极大点，且经验准则一致收敛，则可由极值点的一致性论证验证一致性前提。模型失配时，估计可能趋于仿真参数，极限协方差通常改为夹心形式，不能继续使用正确指定下的信息矩阵逆。

渐近正态性支持参数区间与检验，但不自动控制任意测试分布下的预测风险。Poisson 等模型的损失无界，输入尾部、参数大小与设计条件都会影响有限样本结论；样本数大于维数也不保证泛化可靠。

2.1.5.4 小结

GLM 把条件均值的取值范围和均值方差关系纳入模型，在同一似然与 IRLS 框架下处理多类响应。它扩展的是分布和链接，仍需检验线性预测器、观测独立性与分布假设是否合适。有限解存在、算法收敛和统计一致性是不同问题；参数置信区间与未来响应预测区间也有不同含义。若线性预测器遗漏单特征的弯曲趋势，可以在下一小节中将线性项替换为光滑函数。

2.1.6 广义可加模型 (GAM)

楼龄对价格的影响可能先降得快、之后趋缓，用一个斜率难以概括，而完全自由的多维函数又需要更多数据。**广义可加模型** (generalized additive model, GAM) 让每个特征贡献一个一维函数，再把这些贡献相加。Hastie 与 Tibshirani 在 1986 年系统阐述了这一扩展：保留 GLM 的分布与链接，用平滑函数替代单特征的线性项。它保留逐特征检查作用形状的便利，并通过可加结构限制需要学习的交互关系¹⁷。

¹⁷ T. Hastie, R. Tibshirani, *Generalized Additive Models In Statistical Science*, 1986, vol. 1, no. 3, pp. 297–310

2.1.6.1 模型结构

沿用 GLM 的响应分布与链接，GAM 写成

$$g(\mu_i) = b + \sum_{j=1}^d f_j(x_{i,j}), \quad \sum_{i=1}^n f_j(x_{i,j}) = 0. \quad (2.25)$$

中心化约束把常数部分留给截距 b ，使各 f_j 描述相对于样本平均水平的变化。它消除了常数在各项之间任意移动的歧义，却不能解决所有不可识别问题：若两个输入完全相同，两个光滑项仍可能互相抵消，需要进一步约束或合并表示。

恒等链接下， f_j 直接作用于条件均值；非线性链接下，它作用于链接尺度。例如可加 logistic 模型中的函数描述对数几率的变化，不能直接当作概率变化。没有显式交互项时，GAM 不能表达任意多维关系；可加入少数 $f_{j,k}(x_j, x_k)$ 补充必要交互，并约束其与主效应重叠的部分。每项可画图并不意味着它具有因果含义，相关特征仍会影响解释。

2.1.6.2 参数学习

用预定样条基展开 $f_j(x) = \sum_{k=1}^{K_j} \gamma_{j,k} B_{j,k}(x)$, 再惩罚曲率。若采用 $\int [f_j''(x)]^2 dx$, 其矩阵形式为 $\boldsymbol{\gamma}_j^\top \mathbf{S}_j \boldsymbol{\gamma}_j$, 其中

$$(\mathbf{S}_j)_{k,l} = \int B_{j,k}''(x) B_{j,l}''(x) dx.$$

任意 $\mathbf{a}$ 满足 $\mathbf{a}^\top \mathbf{S}_j \mathbf{a} = \int (\sum_k a_k B_{j,k}''(x))^2 dx \geq 0$, 故惩罚矩阵半正定。常数和一次函数的二阶导数为零, 属于该惩罚的零空间, 因此 λ_j 很大时通常留下线性成分, 而不是自动把整项置零。

在满足中心化约束的坐标中, 把截距和全部基系数组成 $\boldsymbol{\gamma}$, 设计矩阵记为 $\mathbf{B}$, 相应块惩罚记为 $\mathbf{S}_\lambda$, 可最小化

$$-\ell(\boldsymbol{\gamma}) + \frac{1}{2} \boldsymbol{\gamma}^\top \mathbf{S}_\lambda \boldsymbol{\gamma}.$$

固定平滑参数 λ_j 时, 惩罚 IRLS 的每一步求解

$$(\mathbf{B}^\top \mathbf{W} \mathbf{B} + \mathbf{S}_\lambda) \boldsymbol{\gamma}^+ = \mathbf{B}^\top \mathbf{W} \mathbf{z}^{\text{work}}. \quad (2.26)$$

只有数据曲率与惩罚共同排除全部未约束零方向时, 系数解才唯一。设展开后总维数为 q , 稠密加权平方子问题约需 $O(nq^2 + q^3)$ 运算; 稀疏局部基可以改变这个代价。预测则需计算相应基函数, 不能始终按原始维数 d 计为 $O(d)$ 。

高斯恒等链接下也可采用**回代拟合** (backfitting): 固定其他函数, 以部分残差 $y_i - b - \sum_{k \neq j} f_k(x_{i,k})$ 拟合第 j 项, 再中心化并循环。对固定有限基、正定惩罚平方系统, 精确块更新等价于块 Gauss-Seidel 迭代, 收敛到唯一解; 若任意组合不对应共同目标的平滑器, 则需另行证明。非高斯响应可把这种循环嵌入工作响应更新。

平滑参数决定拟合曲线的曲折程度, 可用交叉验证、广义交叉验证, 或采用混合模型解释下的受限最大似然选择。相关工作发展了多个平滑参数的稳定估计与数值方法, 但并不保证任意设计中都获得全局最优超参数; 参数选择带来的不确定性也不能被固定平滑参数的条件区间完全反映¹⁸。

2.1.6.3 小结

GAM 在链接尺度上保留可加结构, 用每个特征的函数替代单一斜率。它在真实关系接近可加、交互有限时降低估计负担, 代价是不能自动表示未指定的复杂交互。平滑强度、基维数与相关特征共同影响结果。可解释性与预测精度也不是固定的此消彼长关系: 若可加结构接近真实规律, 约束本身就可能同时帮助解释与泛化。

¹⁸ S. N. Wood, *Fast Stable Restricted Maximum Likelihood and Marginal Likelihood Estimation of Semiparametric Generalized Linear Models* In Journal of the Royal Statistical Society: Series B (Statistical Methodology), 2011, vol. 73, no. 1, pp. 3–36

2.1.7 模型对比与总结

本节各方法的共同点是可利用线性预测器或线性基展开，差异则落在预测对象和约束方式上。表2.3保留这些最直接影响选择的区别。平方损失、分位数损失和 ϵ 不敏感损失本身都不要响应高斯；只有明确采用概率模型时，分布假设才成为似然和推断的依据。

方法	拟合目标	主要结构或约束	需要单独检查的边界
OLS	平方损失下的条件均值	固定线性特征展开	秩、共线性、模型失配
正则化线性回归	拟合与惩罚的折中	稠密收缩、坐标或组稀疏	尺度、调参、选择稳定性
分位数回归	指定条件分位数	非对称线性残差损失	尾部信息、交叉、杠杆点
SVR	容忍带外的残差损失	二次范数与可选核展开	核选择、样本展开规模
GLM	指定分布的似然	均值链接与线性预测器	分布、解的存在与设计
GAM	惩罚似然或平方损失	可加函数与平滑约束	交互遗漏、可识别性

表 2.3 线性回归及其扩展的比较。表中列出本节采用的基本形式；分位数回归和 GLM 也可加正则，概率区间的构造还需额外假设或校准。

Lasso 与 Group Lasso 在参数或参数组上产生零值，SVR 在训练样本展开上产生零值，两者不能按同一个“稀疏度”直接比较。核岭回归则把平方损失和函数范数结合，一般没有 SVR 的零损失带，其与高斯过程后验均值的联系将在第2.4.1.3节完整证明。PCR、PLS 与显式正则化处理的是相近的共线性问题，但分别在表示和参数约束上作取舍。

响应的观测机制还可能超出上述模型：Tobit 模型处理潜在连续响应被删失后的观测，不能把删失与截断混为一谈；生存分析中的 Cox 模型通过风险函数处理事件时间与删失。它们说明选择回归方法时，除了函数形状，还需明确实际观测到了什么。若主要困难来自不同输入区域的局部关系，而不是全局系数的约束，就可以转向下一节的邻域方法。

2.2 基于邻域的回归

沿用第1.2.2节定义的邻域，回归需要把附近样本的响应变成一个数值预测。 k -NN 采用局部常数平均，LOESS 在邻域内拟合低阶多项式；二者的区别主要在局部模型与平滑尺度。下面分别说明响应噪声、邻域大小和查询成本怎样影响预测。

2.2.1 k 近邻回归 (k -NN)

k -NN 回归以邻居响应的平均估计条件均值。Stone 关于非参数回归一致性的工作为这类方法提供了理论依据；具体一致性条件与收敛对象将在下文区分¹⁹。

¹⁹ C. J. Stone, *Consistent Nonparametric Regression* In The Annals of Statistics, 1977, vol. 5, no. 4, pp. 595–620

2.2.1.1 模型结构

对查询点 $\mathbf{x}$ ，令 $I_k(\mathbf{x})$ 为恰好包含 k 个最近样本的索引集，定义

$$\hat{m}_{n,k}(\mathbf{x}) = \frac{1}{k} \sum_{i \in I_k(\mathbf{x})} y_i, \quad 1 \leq k \leq n. \quad (2.27)$$

距离并列时应采用不依赖响应的固定规则或独立随机化。欧氏距离适合尺度已经可比的数值特征；若使用 Mahalanobis 距离，则还要估计或指定度量矩阵。特征标准化应基于训练集，类别特征的相似性也需另行定义。

$k = 1$ 保留最近样本的响应噪声， $k = n$ 退化为全局平均；两者的偏差大小仍取决于真实函数，不能仅由 k 断言。距离加权版本写成 $\sum_i a_i(\mathbf{x}) y_i$ ，其中 $a_i \geq 0$ 、 $\sum_i a_i = 1$ ，权重可在邻域外置零。使用距离倒数时必须规定零距离的处理，例如仅对重合输入的响应平均，不能直接除以零。

2.2.1.2 参数学习

基本 k -NN 回归不拟合固定维数的系数，但仍需保存训练样本、建立可选索引，并通过验证选择 k 和距离设定。朴素查询计算全部距离需要 $O(nd)$ 运算，再通过选择算法找出前 k 个邻居；不必为此完整排序全部距离。

KD 树、Ball 树等索引在适合的低维几何结构下可以减少搜索量，但查询复杂度依赖数据分布、查询位置与维数，最坏情况仍可能接近扫描。近似近邻以容许搜索误差换取计算节约，预测误差分析需把邻居近似的影响计入。不存在普适的“超过某个维数索引便无效”或“ k 应固定在某个小区间”的阈值。

交叉验证比较候选 k 时，每个验证点只能使用相应训练折作为邻居库。用训练点预测自身会产生过于乐观的误差，尤其 $k = 1$ 时可以直接复现训练响应。若从同一响应数据学习距离或选择邻居，下面仅条件于输入的简单证明也不能原样套用。

2.2.1.3 理论分析

k -NN 的统计目标是固定查询点处的条件均值，而不是一组经迭代优化的参数。下面假设训练样本独立同分布，且邻居并列规则不依赖响应；所得结论依次是条件均方误差界、依概率点态一致性，以及附加有界条件下的均方一致性。这些点态或条件结论不能推出所有输入上一致收敛，也不给出无分布条件的有限样本速率。

收敛性分析 精确 k -NN 回归在选定邻居后直接计算响应均值，没有反复更新模型参数的训练过程，因此不存在这类迭代的优化收敛问题。若使用近似近邻搜索，计算结果还可能偏离精确邻居集；这种搜索误差需要与有

限样本造成的统计误差分开评价。

泛化分析 局部平均面临两个相反要求：邻域应足够小，使邻居的条件均值接近查询点；邻居又应足够多，使噪声被平均。先在明确的光滑条件下给出可直接证明的结果，再说明它与普适一致性的区别。

定理 2.8 k -NN 回归的条件误差与点态一致性 设 $(\mathbf{X}_i, Y_i)$ 独立同分布， $Y_i = m(\mathbf{X}_i) + \varepsilon_i$ ， $\mathbb{E}[\varepsilon_i | \mathbf{X}_i] = 0$ ， $\text{Var}(\varepsilon_i | \mathbf{X}_i) \leq \sigma^2$ 。固定查询点 $\mathbf{x}$ ，假设 m 在支持集与该点上为 L -Lipschitz 函数。记

$$R_{n,k}(\mathbf{x}) = \max_{i \in I_k(\mathbf{x})} \|\mathbf{X}_i - \mathbf{x}\|_2.$$

条件于全部训练输入及独立的并列处理随机数所生成的信息 $\mathcal{F}_n$ ，有

$$\mathbb{E}[(\hat{m}_{n,k}(\mathbf{x}) - m(\mathbf{x}))^2 | \mathcal{F}_n] \leq L^2 R_{n,k}(\mathbf{x})^2 + \frac{\sigma^2}{k}.$$

若 $\mathbf{x}$ 的每个正半径球都有正概率，且确定序列 $k_n \rightarrow \infty$ 、 $k_n/n \rightarrow 0$ ，则 $\hat{m}_{n,k_n}(\mathbf{x}) \rightarrow m(\mathbf{x})$ 依概率成立。若另有 $|m| \leq M < \infty$ ，则也有点态均方一致性。

证明. 条件于 $\mathcal{F}_n$ ，邻居集固定，估计误差写成偏差与零均值噪声之和：

$$\hat{m}_{n,k}(\mathbf{x}) - m(\mathbf{x}) = \frac{1}{k} \sum_{i \in I_k} [m(\mathbf{X}_i) - m(\mathbf{x})] + \frac{1}{k} \sum_{i \in I_k} \varepsilon_i.$$

第一项绝对值不超过 $L R_{n,k}$ ，第二项的条件方差不超过 σ^2/k ，交叉项条件期望为零，故得到误差界。

固定 $r > 0$ ，记 $p_r = \mathbb{P}(\|\mathbf{X} - \mathbf{x}\|_2 \leq r) > 0$ ，球内样本数 $N_n(r)$ 服从 $\text{Bin}(n, p_r)$ 。充分大 n 下有 $k_n/n < p_r/2$ ，于是

$$\mathbb{P}(R_{n,k_n} > r) = \mathbb{P}(N_n(r) < k_n) \leq \frac{4(1 - p_r)}{n p_r} \rightarrow 0.$$

当 $p_r = 1$ 时左端直接为零。故偏差依概率趋于零；噪声项的二阶矩至多 $\sigma^2/k_n \rightarrow 0$ ，由切比雪夫不等式也依概率趋于零，得到点态一致性。

若 $|m| \leq M$ ，偏差还不超过 $2M$ 。对任意 $r > 0$ 按半径事件分解期望，得到

$$\mathbb{E}[(\hat{m}_{n,k_n}(\mathbf{x}) - m(\mathbf{x}))^2] \leq L^2 r^2 + 4M^2 \mathbb{P}(R_{n,k_n} > r) + \frac{\sigma^2}{k_n}.$$

先令 $n \rightarrow \infty$ ，再令 $r \downarrow 0$ ，右侧趋于零，得到点态均方一致性。 ■

Stone 型普适 L^2 一致性更一般：在有限维欧氏空间及适当的、与响应无关的近邻并列处理下，对任意满足 $\mathbb{E}[Y^2] < \infty$ 的数据分布， $k_n \rightarrow \infty$ 、

$k_n/n \rightarrow 0$ 可使独立查询输入上的积分均方误差趋于零。它不要求 m 为 Lipschitz 函数, 也不保证每个指定点都收敛。其证明需要近邻权重的几何控制与对一般可测函数的逼近, 不能用“距离近所以函数值近”替代; 上面的定理给出的是具有额外光滑条件的点态证明, 而非普适定理的证明。

一致性也不提供无分布条件的统一速率。若查询点附近存在正且有界的密度, 半径的典型尺度约为 $(k/n)^{1/d}$, Lipschitz 误差界提示平衡 $(k/n)^{2/d}$ 与 $1/k$ 。在相应正则条件下, 这给出 k 约为 $n^{2/(d+2)}$ 的量级及 $n^{-2/(d+2)}$ 的风险尺度; 这只是针对该光滑类别的分析, 不能把任意高阶光滑函数的最优速率都赋给局部常数 k -NN 回归。有效维数增大时, 为保持小邻域所需的样本会显著增加。

2.2.1.4 小结

k -NN 回归通过保留训练样本和局部平均避免了固定全局函数形式, 代价是查询计算、存储以及对距离表示的依赖。随样本量增加, 应让邻居数与相对邻域尺度同时调整, 固定 k 通常不能消除响应噪声。高维中的困难来自局部数据稀疏与无关坐标, 而非“近邻方法只能表示简单函数”; 良好的低维表示可能帮助它, 但需要额外的数据与学习依据。

2.2.2 局部加权回归 (LOESS)

当价格随面积在邻域中已有清晰斜率时, 只取邻居均值会丢失这部分结构, 尤其在数据边界的一侧邻域中更明显。**局部加权回归** (locally estimated scatterplot smoothing, LOESS) 在每个查询点附近拟合低阶多项式, 按距离给邻近样本较大权重。Cleveland 在 1979 年介绍的稳健局部加权散点平滑还加入残差重加权, 以减轻异常响应的影响; LOWESS 与 LOESS 在具体实现中的阶数、邻域和稳健化约定应分别说明²⁰。

2.2.2.1 模型结构

对查询点 $\mathbf{x}_0$, 令 $K_i = K(\|\mathbf{x}_i - \mathbf{x}_0\|_2/h)$, 其中 $K \geq 0$ 、带宽 $h > 0$ 。局部多项式通过

$$\hat{\mathbf{a}}(\mathbf{x}_0) \in \arg \min_{\mathbf{a}} \sum_i K_i (y_i - \mathbf{p}(\mathbf{x}_i - \mathbf{x}_0)^\top \mathbf{a})^2 \quad (2.28)$$

得到预测 $\hat{m}(\mathbf{x}_0) = \mathbf{p}(\mathbf{0})^\top \hat{\mathbf{a}}(\mathbf{x}_0)$ 。局部常数取 $\mathbf{p} = 1$, 局部线性取 $\mathbf{p}(\mathbf{u}) = (1, \mathbf{u}^\top)^\top$, 局部二次再加入 $u_j u_k$ 、 $j \leq k$; 避免把重复交叉项加入设计而人为制造秩亏。

常见距离核包括高斯核、Epanechnikov 核及三立方核 $K(\mathbf{u}) = (1 - |\mathbf{u}|^3)^3 \mathbf{1}\{|\mathbf{u}| < 1\}$ 。此处的核是非负局部权重函数, 与核 SVR 要求生成半正定 Gram 矩阵的核不是同一条件。带宽可以固定, 也可以由包含指定比例最近邻的半径决定; 后一种选择使稀疏区域的邻域变宽, 同时也可能增大

²⁰ W. S. Cleveland, *Robust Locally Weighted Regression and Smoothing Scatterplots* In *Journal of the American Statistical Association*, 1979, vol. 74, no. 368, pp. 829–836

局部近似偏差。

图2.4比较同一个查询点上的两种局部预测。左图把选中邻居的响应压缩为一个均值，右图还利用了邻域内输入变化与响应变化的对应关系。图中的水平线与斜线都只服务于当前查询点；换一个 x_0 ，邻域、权重和拟合系数都会重新计算，因此这些局部直线可以共同描述弯曲的整体关系。




图 2.4 同一查询点上的邻域平均与局部线性拟合。横、纵轴均无量纲，所有点均为构造样本；空心点为未使用样本，蓝色实心点为本次使用的四个样本，菱形为 $x_0 = 2.8$ 处的预测。左图取 $k = 4$ 、等权平均，预测约为 1.238；右图取 $h = 1.2$ 与三立方距离权重，不做残差重加权，局部线性预测约为 1.171。浅色带标出各自的邻域，两图同时改变了局部函数形式和权重，不据此断言某种方法总是更准。

2.2.2.2 参数学习

设局部基设计为 $\mathbf{P}$ ，权重矩阵为 $\mathbf{W} = \text{diag}(\mathbf{K}_i)$ 。若 $\mathbf{P}^\top \mathbf{W} \mathbf{P}$ 可逆，便可解加权正规方程得到局部系数；实际使用 $\mathbf{W}^{1/2} \mathbf{P}$ 的 QR 分解等方法更合适。邻域无样本或有效点不足以确定多项式时，应扩大邻域、降低阶数或明确回退规则，不能直接使用逆矩阵公式。

一维局部线性形式可写得更清楚。令 $u_i = x_i - x_0$ ， $S_j = \sum_i K_i u_i^j$ 、 $T_j = \sum_i K_i u_i^j y_i$ ，并记 $\Delta = S_0 S_2 - S_1^2$ 。方程组为

$$\begin{pmatrix} S_0 & S_1 \\ S_1 & S_2 \end{pmatrix} \begin{pmatrix} \hat{a} \\ \hat{b} \end{pmatrix} = \begin{pmatrix} T_0 \\ T_1 \end{pmatrix}.$$

若 $\Delta > 0$ ，查询点上的截距可表示为

$$\hat{m}(x_0) = \sum_i l_i y_i, \quad l_i = \frac{K_i (S_2 - u_i S_1)}{\Delta}. \quad (2.29)$$

对非负核权重， $\Delta = \sum_{i < j} K_i K_j (u_i - u_j)^2$ ，所以至少需要两个不同输入具有正权重。即使 $\Delta > 0$ ，接近退化的设计也可能产生很大的 l_i 。

固定带宽与只依赖输入的权重时, 估计是响应 $\mathbf{y}$ 的线性函数。稳健 LOESS 则在初次拟合后根据残差增加降权系数, 再重复局部拟合; 权重一旦依赖响应, 整体估计便不再是固定的线性平滑算子, 下面的固定权重方差公式不能直接沿用。若一个查询使用 n_{loc} 个有效样本、 q 个局部基函数, 稠密拟合约需 $O(n_{\text{loc}}q^2 + q^3)$ 运算, 另加邻域查询成本。

2.2.2.3 理论分析

局部线性回归的计算与统计性质都围绕一个固定查询点展开。给定输入后, 先考察加权最小二乘是否可解; 在一维独立同分布随机设计和确定带宽序列下, 再给出依概率的局部偏差方差展开。局部线性再现与渐近展开不能推出无条件风险最优, 也不能说明任意稳健重加权实现都会收敛。

收敛性分析 固定查询点、带宽和邻域权重后, 局部多项式拟合是加权最小二乘问题。加权设计满秩时, 求解线性系统即可得到唯一系数; 秩亏时则需降阶、正则化或规定回退方式。若加入依赖残差的稳健重加权, 外层权重也随拟合改变, 单次加权最小二乘的可解性不再等于整个迭代必然收敛, 仍需检查相应目标和停止准则。

泛化分析 局部线性拟合的核心收益是精确再现一次函数。由式(2.29)直接求和,

$$\sum_i l_i = 1, \quad \sum_i l_i u_i = 0.$$

因此当 $m(x) = a + bx$ 时, $\sum_i l_i m(x_i) = m(x_0)$, 不要求样本在 x_0 两侧对称。第二个恒等式解释了局部线性为何能消去一阶趋势造成的偏差。

最终权重 l_i 却不必非负。例如 $x_0 = 0$ 、 $x_1 = 0.1$ 、 $x_2 = 0.2$ 、 $K_1 = K_2 = 1$ 时, $(l_1, l_2) = (2, -1)$ 。对构造响应 $y_i = x_i$, 局部线性预测为 0, 局部常数预测为 0.15。若这两个响应分别加入独立方差为 σ^2 的噪声, 两种预测的方差则为 $5\sigma^2$ 与 $\sigma^2/2$ 。消除线性偏差需要付出方差代价, 不能直接推出局部线性总有更小风险。

更一般地, 固定输入且误差条件独立、方差 $v(x_i) \leq \sigma^2$ 时,

$$B_n = \sum_i l_i [m(x_i) - m(x_0)], \quad V_n = \sum_i l_i^2 v(x_i)$$

分别为条件偏差和方差。若 m 在覆盖有效邻域的区间二阶连续可微且 $|m''| \leq M_2$, 用一次项抵消与 Taylor 余项可得

$$|B_n| \leq \frac{M_2}{2} \sum_i |l_i| u_i^2, \quad V_n \leq \sigma^2 \sum_i l_i^2.$$

绝对值不能删去, 也不能把这些权重当作凸组合套用 k -NN 回归误差界。

在内部点及规则随机设计下，上述精确公式可进一步化为熟悉的渐近偏差方差展开。局部多项式的系统分析见 Fan 与 Gijbels 的专著；下面明确给出本章使用的条件与推导²¹。

以下余项随随机训练输入变化。记 $Z_n = o_P(a_n)$ 表示 Z_n/a_n 依概率趋于零， $Z_n = O_P(a_n)$ 表示该比值依概率有界：对任意 $\delta > 0$ ，存在有限 M 使充分大的 n 满足 $\mathbb{P}(|Z_n/a_n| > M) < \delta$ 。

²¹ J. Fan, I. Gijbels, *Local Polynomial Modelling and Its Applications*, Chapman & Hall, 1996

定理 2.9 一维内部点的局部线性展开 设 (X_i, Y_i) 独立同分布，固定内部点 x_0 附近的输入密度 p 连续且 $p(x_0) > 0$ ，回归函数 m 二阶连续可微，条件方差 v 在 x_0 连续且有限。核 K 非负、有界、对称，支撑在 $[-1, 1]$ ，满足 $\int K = 1$ 和 $\mu_2 = \int u^2 K(u) du > 0$ 。取确定带宽 $h \rightarrow 0, nh \rightarrow \infty$ ， $K_h = K((X_i - x_0)/h)$ ，记 $R(K) = \int K(u)^2 du$ 。在可逆事件上，条件偏差与方差满足

$$B_n = \frac{1}{2} m''(x_0) \mu_2 h^2 + o_P(h^2),$$

$$V_n = \frac{v(x_0) R(K)}{nh p(x_0)} + o_P((nh)^{-1}).$$

可逆事件的概率趋于 1；在退化事件上须另设估计值。

证明. 令 $\mu_j = \int u^j K(u) du$ 。变量替换给出，对 $j = 0, 1, 2, 3$,

$$\frac{\mathbb{E} S_j}{nh^{j+1}} = \int u^j K(u) p(x_0 + hu) du \rightarrow p(x_0) \mu_j.$$

局部有界密度与有界紧支撑核给出 $\text{Var}(S_j/(nh^{j+1})) = O((nh)^{-1})$ ，故相应归一化矩依概率趋于 $p(x_0) \mu_j$ 。由 $\mu_1 = \mu_3 = 0$,

$$\frac{\Delta}{n^2 h^4} \xrightarrow{P} p(x_0)^2 \mu_2 > 0, \quad \sum_i l_i u_i^2 = \frac{S_2^2 - S_1 S_3}{\Delta} = h^2 \mu_2 + o_P(h^2).$$

此外 $\sum_i |l_i| \leq S_0(S_2 + h|S_1|)/\Delta = O_P(1)$ 。将 $m(X_i)$ 在 x_0 处展开，常数与一次项分别由权重恒等式再现和抵消；二阶连续性使 $|u_i| \leq h$ 内的余项一致为 $o(h^2)$ ，于是得到偏差公式。

为求方差，令 $A_j = \sum_i K_i^2 v(X_i) u_i^j$ ， $j = 0, 1, 2$ 。同样的均值与方差估计给出

$$\frac{A_j}{nh^{j+1}} \xrightarrow{P} p(x_0) v(x_0) \int u^j K(u)^2 du.$$

把权重公式代入精确条件方差，得到

$$V_n = \frac{S_2^2 A_0 - 2S_2 S_1 A_1 + S_1^2 A_2}{\Delta^2}.$$

分子第一项与分母的上述极限给出 $v(x_0) R(K)/(nh p(x_0))$ ，含 S_1 的两项为

较小阶，方差公式成立。 ■

当偏差和方差的领先系数都为正时，平衡 h^4 与 $1/(nh)$ 提示 h 取 $n^{-1/5}$ 量级，对应条件风险的 $n^{-4/5}$ 尺度。若曲率为零，领先偏差项消失，不能仍按同一常数求最佳带宽。这些是随机设计下依概率成立的条件展开；改成无条件均方误差展开还需控制退化设计和余项的可积性。边界点的核矩被截断，也不能直接沿用内部点常数。

2.2.2.4 支持局部常数 (Nadaraya-Watson 核平滑)

在式(2.28)中只拟合截距，对截距求导便得到 **Nadaraya-Watson 核平滑** (Nadaraya-Watson kernel smoothing)

$$\hat{m}_{\text{NW}}(x_0) = \frac{\sum_i K_i y_i}{\sum_i K_i}, \quad \sum_i K_i > 0. \quad (2.30)$$

它与局部多项式使用相同的邻域权重，但只作加权平均。Nadaraya 与 Watson 分别研究了这一核回归路线；具体带宽和设计条件仍须与所用理论结果对应²²。

在联合密度存在的设定下， $m(x)p(x) = \int y p(x, y) dy$ ，所以归一化核响应和可估计 $m(x)p(x)$ ，核计数可估计 $p(x)$ ，比值便近似条件均值。

局部常数权重和为 1，但通常不满足一阶矩为零。因此一侧邻域的斜率可能带来一阶偏差。以一维内部点为例，把经验核和换为总体积分，记总体平滑值为 $m_h(x_0)$ 。在 m, p 二阶连续可微、 $p(x_0) > 0$ 及前述对称紧支撑核条件下，对分子 $\int K(u)m(x_0+hu)p(x_0+hu) du$ 和分母 $\int K(u)p(x_0+hu) du$ 分别展开，得到

$$m_h(x_0) - m(x_0) = \mu_2 h^2 \left[\frac{m''(x_0)}{2} + \frac{m'(x_0)p'(x_0)}{p(x_0)} \right] + o(h^2).$$

后一项反映设计密度不均匀的影响。局部线性消去这项并改善边界处的一阶偏差，但其负权重可能增大方差，所以选择仍应看总风险。

2.2.2.5 小结

LOESS 用局部斜率或曲率补充局部平均，适合观察低维输入与响应之间的平滑关系。其有效性取决于局部数据量、设计秩、带宽和光滑程度；稳健重加权可以减轻部分异常响应影响，却没有消除所有异常点风险。它不提供一组统一的全局斜率，但局部曲线和局部导数仍有解释价值，不能简单等同于“不可解释”。

²² E. A. Nadaraya, *On Estimating Regression* In *Theory of Probability & Its Applications*, 1964, vol. 9, no. 1, pp. 141–142; G. S. Watson, *Smooth Regression Analysis* In *Sankhyā: The Indian Journal of Statistics, Series A*, 1964, vol. 26, no. 4, pp. 359–372

2.2.3 模型对比与总结

k -NN 回归与 LOESS 都根据查询点选择局部数据，差别在于是否拟合邻域内的趋势。 k -NN 回归的均匀权重便于控制方差，局部线性权重能再现一次函数，却可能为负。内部点、边界点、对称设计与不均匀设计下，两者的偏差阶并不总相同，因此不能无条件声称 LOESS 的风险严格小于 k -NN 回归。

平滑样条沿另一条路线控制函数曲率，径向基函数网络则先选中心再学习全局展开系数。它们与邻域方法都使用局部性或相似性，但目标并不相同。尤其 Nadaraya-Watson 的系数由查询点归一化得到，核岭回归的训练系数则由整个 Gram 矩阵耦合求解；二者一般不等价。选择方法时应同时考虑局部光滑性、输入的有效维数和查询预算，而不是把所有带核权重的方法视为同一个模型。

2.3 基于树与规则的回归

第1.2.3节已经给出条件分支与区域预测的共同结构。本节关注回归时怎样按响应损失选择区域，并确定叶内预测。CART 采用递归划分，模型树在叶内加入线性趋势，MARS 用连续铰链基表达阈值及交互。MARS 的基函数可以重叠，并不构成标准决策树；把它放在这里，是为了比较不同的条件与分段表达。

2.3.1 CART 回归树

分类与回归树（classification and regression trees, CART）将递归二分、叶内估计和复杂度剪枝组织成统一框架。Breiman 等人在 1984 年的专著中系统阐述了这套方法，把数据决定的分区与树的规模控制联系起来。回归情形通常用平方误差评价分裂，再通过独立验证选择树的规模；这一流程将在下面分别展开²³。

第3.3.3节的分类 CART 共享递归二分与代价复杂度剪枝。任务差异落在分裂和叶输出上：本节按响应平方误差选择分区并输出叶均值，分类树按类别不纯度或误分类代价分裂，并输出类别标签或类别比例。

²³ L. Breiman, J. H. Friedman, R. A. Olshen, C. J. Stone, *Classification and Regression Trees*, Wadsworth International Group, 1984, 1st ed.


2.3.1.1 模型结构

设树 T 的叶区域为 $R_1, \dots, R_M$ ，则

$$f_T(\mathbf{x}) = \sum_{m=1}^M c_m \mathbf{1}\{\mathbf{x} \in R_m\}. \quad (2.31)$$

数值特征上的节点规则通常为 $x_j \leq s$ 与 $x_j > s$ ，递归后形成轴对齐区域；类别特征则可按类别子集分支，不宜继续称为普通欧氏矩形。缺失值并

(a) 给定阈值树



(b) 一维分段常数预测




图 2.5 给定阈值树与分段常数预测。六个无量纲教学样本按 x 递增排列；按 $x \leq 2$ 及右分支上的 $x \leq 4$ 划分后，三组响应分别为 (1, 2)、(4, 5)、(2, 3)，叶均值为 1.5、4.5、2.5。蓝色点表示样本，红色虚线表示预测，黄色竖线表示阈值；阈值处实心、空心端点区分取与不取该值。右图只显示 $0 \leq x \leq 6$ ，树结构预先给定。

非由树结构自动解决，还需指定缺失方向或其他规则。例如，**替代分裂** (surrogate split) 在主测试特征缺失时，用其他特征的测试尽量复现主分裂的左右分配。

固定非空叶的样本索引集 I_m 后，令 $\bar{y}_m = |I_m|^{-1} \sum_{i \in I_m} y_i$ ，有

$$\sum_{i \in I_m} (y_i - c)^2 = \sum_{i \in I_m} (y_i - \bar{y}_m)^2 + |I_m|(c - \bar{y}_m)^2.$$

因此 $c_m = \bar{y}_m$ 在平方损失下最优。改用绝对或分位数损失时，叶预测相应变为中位数或分位数；模型结构与损失选择仍然可以分开。

图2.5把一棵给定的阈值树展开为预测函数。沿树走到同一叶的输入共享一个预测值，所以一维常数叶回归树产生水平分段，而阈值处可以跳跃。图中每个叶的数值都来自该叶的两条响应，后面的学习问题才是如何从候选阈值中选出这些分区。

2.3.1.2 参数学习

在当前节点内，算法枚举特征与候选阈值，选择子节点平方误差和最小的分裂。对两个非空子节点，记样本数为 n_L, n_R ，均值为 $\bar{y}_L, \bar{y}_R$ ，则分裂增益可精确写成

$$\Delta_{\text{split}} = \text{SSE}_{\text{parent}} - \text{SSE}_L - \text{SSE}_R = \frac{n_L n_R}{n_L + n_R} (\bar{y}_L - \bar{y}_R)^2. \quad (2.32)$$

证明只需把两个子节点响应分别围绕自己的均值展开，再利用父均值为加权平均。该式说明增益同时考虑两组均值差异和样本量。

连续特征只需在相邻不同取值之间设候选切分，排好序后用累计和、平方和更新各侧 SSE。类别子集有更多候选；在无额外分裂约束的平方误差二分问题中，可先按类别响应均值排序再考虑相邻分组，但带最小样本数、权重或其他限制时须重新检查相应结论。停止条件可限制最大深度、最小叶样本数和最低增益。贪心选择只保证当前节点在候选集中的最佳切分，不保证整棵树全局最优。

树生长后，用叶数惩罚控制规模。固定一个已生长的有限二叉树 T_0 ，对其剪枝子树 T 定义

$$R_\alpha(T) = \sum_{m \in \text{leaves}(T)} \text{SSE}_m + \alpha |\text{leaves}(T)|, \quad \alpha \geq 0. \quad (2.33)$$

代价复杂度剪枝 (cost-complexity pruning) 在保留局部拟合与减少叶数之间作折中。临界 α 处可能出现多个最优子树，唯一性需要额外的并列规则。

定理 2.10 固定生长树内的最优剪枝 设 $Q_\alpha(v)$ 为从 T_0 的节点 v 出发可得到的所有剪枝子树的最小代价。若 v 是原始叶，则 $Q_\alpha(v) = \text{SSE}_v + \alpha$ ；若 v 有左右孩子 v_L, v_R ，则

$$Q_\alpha(v) = \min\{\text{SSE}_v + \alpha, Q_\alpha(v_L) + Q_\alpha(v_R)\}.$$

从叶到根计算该递推，并保存每次选择，可得到 R_α 的最优剪枝子树。

证明. 原始叶无其他选择，结论成立。对内部节点，任何合法剪枝子树要么把 v 收缩为一片叶，要么保留分裂。前者代价为 $\text{SSE}_v + \alpha$ ；后者的两个孩子可以独立剪枝，代价相加，归纳假设给出最小和为 $Q_\alpha(v_L) + Q_\alpha(v_R)$ 。这两类穷尽全部选择，因此取最小值即可。相等时两个选择都最优，记录任一并列规则均可返回一个最优解。 ■

固定 α 时，递推只需对每个节点作常数比较，因此在节点 SSE 已知后为 $O(|T_0|)$ 。经典最弱环节方法进一步构造随 α 变化的嵌套剪枝路径，再通过验证选择规模；它优化的仍是给定生长树内的剪枝集合，而不是所有可能的树。交叉验证时，各折的生长与剪枝都应仅使用该折训练集。

2.3.1.3 理论分析

树模型需要分开回答“有限训练集上的建树与剪枝何时结束”和“叶内预测怎样推广到新样本”。前一个问题给出有限步计算结论；后一个问题在结构样本与估计样本独立时，考察固定查询点的条件期望误差及附加条件下的一致性。两类结果都不能推出普通响应自适应 CART 在任意数据分布上的泛化保证。

收敛性分析 在有限训练集上，若每次分裂都产生两个非空子节点，叶数至多为 n ，树的生长会在有限步内终止。对固定生长树，前述剪枝递推也能在有限步内求得该树内的最优剪枝。这些计算性质没有把逐节点贪心搜索变成所有树结构上的全局优化，也没有回答样本量增加时的预测误差是否趋于零。

泛化分析 固定分区后的叶均值看起来类似 k -NN 回归的局部平均，但普通 CART 使用同一批响应选择分裂并估计均值。条件于最终分区，不会自动使被选中的噪声重新保持零均值。分析响应自适应分区需要控制分区类和选择过程，Nobel 关于数据依赖分区的工作正是从这类条件出发；仅写“叶直径趋零、样本数趋无穷”不能代替完整定理²⁴。

用独立数据分别选分区和估计叶均值，可以得到一个透明的有限样本结论。**诚实分区** (honest partitioning) 在这里指：结构样本决定分区，独立估计样本提供叶内被平均的响应。

²⁴ A. Nobel, *Histogram Regression Estimation Using Data-Dependent Partitions* In The Annals of Statistics, 1996, vol. 24, no. 3, pp. 1084–1105

定理 2.11 独立分区下的叶平均误差 用结构样本选定可测分区 Π ，用独立同分布的估计样本计算叶均值。假设估计样本满足零条件均值噪声、条件方差不超过 σ^2 ，回归函数 m 为 L -Lipschitz。固定查询点 $\mathbf{x}$ ，其叶为 A ，其中估计样本数为 N_A ，叶内最大样本距离为 R_A 。条件于结构样本与全部估计输入的信息 $\mathcal{G}$ ，在 $N_A > 0$ 时，

$$\mathbb{E}[(\hat{m}_{\Pi}(\mathbf{x}) - m(\mathbf{x}))^2 \mid \mathcal{G}] \leq L^2 R_A^2 + \frac{\sigma^2}{N_A}.$$

若空叶预测规定为零，则 $N_A = 0$ 时的条件误差为 $m(\mathbf{x})^2$ 。

证明. 条件于 $\mathcal{G}$ ，分区与叶成员已固定，估计响应的噪声仍条件独立且均值为零。非空叶内误差拆为 m 值之差的平均与噪声平均；前者绝对值不超过 LR_A ，后者方差不超过 σ^2/N_A ，交叉项期望为零。空叶使用预定值零，误差直接为 $m(\mathbf{x})^2$ 。 ■

在有界 m 下，若 $R_A \rightarrow 0$ 、 $N_A \rightarrow \infty$ 依概率成立，可用与 k -NN 回归相同的有界偏差分解和噪声界得到点态均方一致性。空叶概率随之趋零。这里的样本数是独立估计样本中的叶成员数，结构样本上的最小叶样本约束并不自动保证它。

普通 CART 不能直接套用这一界。考虑固定输入 $(1, 2, 3)$ 、查询点 2，真实 $m \equiv 0$ ，三个响应独立等概率取 ± 1 。令树必须在 1.5 和 2.5 之间择一分裂，查询叶始终含两个样本。只要左邻或右邻与中间响应同号，最小 SSE 切分就选到同号二点叶，预测平方为 1；该事件概率为 3/4。两侧均异号时预测为零，故实际风险为 3/4，大于机械套用 σ^2/N_A 得到的 1/2。该反例

否定的是独立平均公式的直接挪用，并不声称所有 CART 程序都不一致。

有限样本下，单棵树还可能对数据扰动敏感，贪心分裂也可能错过只有联合出现才有效的交互。后续的 Bagging、随机森林和梯度提升通过多棵树组合改善某些误差来源，但具体改善仍依赖数据与训练设定，不能把集成当作无条件消除偏差或方差的步骤。

2.3.1.4 支持分段线性叶节点（模型树 M5）

如果每个区域内的价格趋势近似线性，用多片常数叶逼近可能需要很多切分。**模型树**（model tree）在叶内拟合线性模型 $f_m(\mathbf{x}) = b_m + \mathbf{w}_m^T \mathbf{x}_{A_m}$ ，其中 A_m 为该叶使用的特征集。**M5** 是这条路线的代表，用树选择适用区域，再用局部回归描述区域内部的趋势²⁵。

局部样本少时，叶内设计可能秩亏，需要选择变量或正则化。父子节点预测的加权混合可以缓和估计跳跃，但两侧叶模型在共同边界上没有被强制相等，因此这种平滑处理不自动保证函数连续。叶模型也可改为 GLM、岭或 Lasso，不过分裂准则、参数估计与复杂度惩罚需要与新模型配套，不能只替换叶公式就沿用全部 CART 理论。

²⁵ J. R. Quinlan, *Learning with Continuous Classes* In Proceedings of AI'92, 1992, pp. 343–348

2.3.1.5 小结

CART 把回归拆为选分区与叶内估计，阈值规则适合表达局部条件关系。它对输入单位缩放通常不如距离方法敏感，但候选分裂数量、缺失值规则与叶内样本量仍会影响结果。固定生长树内的剪枝可以精确优化，整体建树仍是贪心搜索；同一响应参与选树的自适应性也必须进入统计分析。

2.3.2 多元自适应回归样条（MARS）

树的阈值选择能够适应数据，常数叶却在边界处跳跃。**多元自适应回归样条**（multivariate adaptive regression splines, MARS）把阈值写进连续的铰链基函数，再从数据中选择这些基函数及其乘积。Friedman 在 1991 年提出这一方法，将自适应选择结点与样条展开结合。它在可加模型与树式区域表达之间提供了另一种选择：多个基函数可同时作用于同一输入，预测不再由唯一一片叶决定²⁶。

²⁶ J. H. Friedman, *Multivariate Adaptive Regression Splines* In The Annals of Statistics, 1991, vol. 19, no. 1, pp. 1–67

2.3.2.1 模型结构

对特征 x_j 与结点 t ，**铰链函数**（hinge function）为 $(x_j - t)_+$ 与 $(t - x_j)_+$ ，它们在结点一侧为零，另一侧线性变化。MARS 写成

$$f(\mathbf{x}) = \beta_0 + \sum_{m=1}^M \beta_m B_m(\mathbf{x}), \quad B_m(\mathbf{x}) = \prod_{l=1}^{q_m} [s_{m,l}(x_{j_{m,l}} - t_{m,l})]_+, \quad (2.34)$$

其中 $s_{m,l} \in \{-1, 1\}$, q_m 为该基的因子数。通常限制最高交互阶数, 并对同一乘积中重复使用变量设规则, 避免无约束扩张。

单个铰链连续但在结点不可微; 含两个不同变量的乘积如 $(x_1 - 3)_+(5 - x_2)_+$ 在激活区域是二次乘积, 不再是整体分段线性函数。铰链和乘积都连续, 所以有限线性组合连续, 但可微性需要额外平滑构造。严格加性版本只允许单变量基, 增加乘积则允许指定阶数内的交互。

2.3.2.2 参数学习

前向阶段从常数模型开始, 在当前基函数 B_l 、候选变量 j 与候选结点 t 中搜索, 将 $B_l(\mathbf{x})(x_j - t)_+$ 和 $B_l(\mathbf{x})(t - x_j)_+$ 成对加入, 并重新拟合线性系数。选择使训练平方误差下降最多的候选, 直到达到基数、交互阶数或改善量限制。结点与基函数都由响应参与选择, 因此整个训练过程不同于固定设计的一次 OLS。

后向阶段逐个尝试删除非截距基函数, 每次保留训练误差增加最小的删除, 构造不同规模的模型序列。再从序列中按验证误差或广义交叉验证选模型, 而不是一看到 GCV 不再下降就必然停止搜索。常用准则写成

$$\text{GCV} = \frac{\text{SSE}/n}{(1 - C_{\text{eff}}/n)^2}, \quad C_{\text{eff}} < n. \quad (2.35)$$

C_{eff} 是复杂度计数, 既考虑保留的线性系数, 也以附加惩罚近似结点搜索的代价。例如可写成 $q + cK$, 其中 q 是保留设计的秩, K 是采用相应计数约定的结点数, c 是每个结点的附加代价。软件对成对基、交互结点与自由度有不同计数方式, 不能把它一律写成“输入维数乘基数”, 更不能视为数据自适应拟合的精确自由度。

2.3.2.3 理论分析

MARS 先在固定候选集合中作前向与后向搜索, 随后才面对响应参与基选择所产生的统计误差。有限搜索只能给出算法终止和局部改进; 要控制后者, 还需对独立同分布样本、函数空间增长与模型选择另加条件。因此, 有限步停止不能推出全局最优, 样条空间的理论也不能直接推出默认 MARS 贪心程序的风险界。

收敛性分析 固定基函数后, 系数可通过最小二乘求解。前向搜索在给定基数量上限或满足停止准则时结束, 后向阶段每步删除基函数, 也会在有限步内终止。前向与后向步骤都没有搜索全部可能基集合, 因此不能由每一步的局部改善推出全局最优。

泛化分析 如果基函数由同一批响应选择，直接条件于所选设计再套用固定设计 OLS 的无偏性，就忽略了选择偏差。统计分析需要同时考虑系数估计与基函数选择。

样条与低阶交互函数空间有成熟的逼近和统计理论。例如，扩展线性建模研究了多项式样条及张量积表示怎样适应指定的低阶结构。但这类结果中的空间增长、平滑性和模型选择条件必须逐项核对，不能直接变成某个默认 MARS 贪心实现的极小极大保证²⁷。

MARS 输出连续函数并不意味着其估计方差必小于 CART。结点选择可以对样本扰动敏感，多个铰链也可能高度相关。实践中可限制交互阶数和基数量，并用独立验证比较预测；对数据范围外的外推尤其应检查，铰链的线性增长可能在缺少观测支持处产生较大的预测值。

2.3.2.4 小结

MARS 通过自适应结点与铰链乘积表达阈值和交互，在线性系数层面仍可使用最小二乘。其连续性来自基函数，灵活性来自基选择；这两者分别对表示与搜索问题。限制交互能减少候选复杂度，也可能遗漏真实关系，是否合适应由任务和数据判断。

2.3.3 模型对比与总结

CART 用不重叠叶区域和常数预测，模型树在叶内增加线性趋势，MARS 用可重叠的连续基函数及其乘积。前两者沿树路径路由，MARS 需要计算保留的基；叶线性模型可能在边界跳跃，MARS 的基本铰链构造则连续但不必处处可微。三者都允许阈值由数据决定，却使用不同的复杂度控制。

相关工作还从选择偏差和集成方式改进树模型。**条件推断树**(conditional inference tree) 把变量关联检验与分裂位置选择分开，缓解候选切分多的变量更容易被选中的偏向；检验规则和显著性水平仍会影响树大小，不能理解为自动杜绝过拟合²⁸。

2.4 基于概率的回归

本节接续第1.2.4节的概率视角，具体计算未知系数或函数的后验，以及未来响应的预测分布。GLM 已经为响应指定条件分布；这里重点保留参数或函数估计的不确定性，并与响应噪声区分。

分布回归 (distributional regression) 提供了完整条件分布的另一条入口：先选择响应分布族，再让位置、尺度或形状等多个分布参数分别依赖输入。GAMLSS 允许用线性项或平滑项建模这些参数，因而能表达均值不变但条件方差、偏度或尾部随输入变化的情形²⁹。它与只拟合若干分位点

²⁷ C. J. Stone, M. H. Hansen, C. Kooperberg, Y. K. Truong, *Polynomial Splines and Their Tensor Products in Extended Linear Modeling: 1994 Wald Memorial Lecture In The Annals of Statistics*, 1997, vol. 25, no. 4, pp. 1371–1470

²⁸ T. Hothorn, K. Hornik, A. Zeileis, *Unbiased Recursive Partitioning: A Conditional Inference Framework In Journal of Computational and Graphical Statistics*, 2006, vol. 15, no. 3, pp. 651–674

²⁹ R. A. Rigby, D. M. Stasinopoulos, *Generalized Additive Models for Location, Scale and Shape In Journal of the Royal Statistical Society: Series C (Applied Statistics)*, 2005, vol. 54, no. 3, pp. 507–554

不同，也不等同于描述未知函数后验的 GPR；代价是必须选择分布族、链接与各参数的结构，并用适当评分和校准诊断检查整个预测分布。

2.4.1 高斯过程回归 (GPR)

高斯过程回归 (Gaussian process regression, GPR) 通过均值函数和协方差函数规定未知函数在任意有限输入集合上的联合分布。高斯观测噪声使后验与预测分布可以精确计算；权重空间与函数空间两种推导也把它与贝叶斯线性回归、核岭回归联系起来。

高斯过程预测较早已用于时间序列和地统计学，空间预测中的相关方法通常称为克里金 (kriging)。20 世纪 90 年代，Williams 与 Rasmussen 在机器学习语境中讨论了 GPR 及协方差函数参数的学习，并将它与贝叶斯神经网络联系起来³⁰。

³⁰ C. E. Rasmussen, C. K. I. Williams, *Gaussian Processes for Machine Learning*, MIT Press, 2006

2.4.1.1 模型结构

先考虑有限维特征 $\phi(\mathbf{x}) \in \mathbb{R}^p$ ，令 $f(\mathbf{x}) = \phi(\mathbf{x})^\top \mathbf{w}$ 。与 OLS 把 $\mathbf{w}$ 看作待估计固定量不同，**贝叶斯线性回归** (Bayesian linear regression) 对 $\mathbf{w}$ 设置分布，再根据数据更新。使用高斯先验与高斯噪声，更新可通过完成平方得到。

定理 2.12 贝叶斯线性回归的后验与预测 条件于设计矩阵 $\mathbf{X}$ ，设 $\mathbf{w} \sim \mathcal{N}(\mathbf{m}_0, \mathbf{V}_0)$ ，其中 $\mathbf{V}_0 > 0$ ，并设 $\mathbf{y} = \mathbf{X}\mathbf{w} + \varepsilon$ ， $\varepsilon \sim \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I})$ 与 $\mathbf{w}$ 独立， $\sigma^2 > 0$ 。则

$$\begin{aligned}\mathbf{V}_n &= (\mathbf{V}_0^{-1} + \sigma^{-2} \mathbf{X}^\top \mathbf{X})^{-1}, \\ \mathbf{m}_n &= \mathbf{V}_n (\mathbf{V}_0^{-1} \mathbf{m}_0 + \sigma^{-2} \mathbf{X}^\top \mathbf{y}),\end{aligned}$$

且 $\mathbf{w} | \mathbf{X}, \mathbf{y} \sim \mathcal{N}(\mathbf{m}_n, \mathbf{V}_n)$ 。新响应采用独立同方差噪声时，

$$Y_\star | \mathbf{x}_\star, \mathbf{X}, \mathbf{y} \sim \mathcal{N}(\phi_\star^\top \mathbf{m}_n, \phi_\star^\top \mathbf{V}_n \phi_\star + \sigma^2).$$

证明. 先验与似然的负对数相加，去掉与 $\mathbf{w}$ 无关的项后为

$$\frac{1}{2} \mathbf{w}^\top (\mathbf{V}_0^{-1} + \sigma^{-2} \mathbf{X}^\top \mathbf{X}) \mathbf{w} - \mathbf{w}^\top (\mathbf{V}_0^{-1} \mathbf{m}_0 + \sigma^{-2} \mathbf{X}^\top \mathbf{y}).$$

定义定理中的 $\mathbf{V}_n, \mathbf{m}_n$ ，上式等于 $\frac{1}{2} (\mathbf{w} - \mathbf{m}_n)^\top \mathbf{V}_n^{-1} (\mathbf{w} - \mathbf{m}_n)$ 加常数。精度矩阵正定，故该可积密度归一化后就是所述高斯后验。新响应为后验高斯参数的线性变换与独立高斯噪声之和，均值与方差相加即得预测分布。■

若只需用一个参数向量概括后验，可以选择后验密度最大的点。**最大后验估计** (maximum a posteriori estimation, MAP) 就是这种以后验众数作

点估计的规则。固定设计与超参数，且最大值能够取到时，由贝叶斯公式得到

$$\begin{aligned}\hat{\mathbf{w}}_{\text{MAP}} &\in \arg \max_{\mathbf{w}} p(\mathbf{w} | \mathbf{X}, \mathbf{y}) \\ &= \arg \max_{\mathbf{w}} \{\log p(\mathbf{y} | \mathbf{X}, \mathbf{w}) + \log p(\mathbf{w})\}.\end{aligned}\quad (2.36)$$

后验的归一化常数与 $\mathbf{w}$ 无关，因而不影响最大化。MAP 使用后验众数，后验均值则对参数按后验加权平均，两者一般不同。

图 2.6 在二维参数平面上展示这两个目标的差别。似然单独把最优点放在数据偏好的中心；零均值先验则偏好靠近原点的参数。MAP 最小化负对数似然与负对数先验之和，因此落在二者共同决定的位置，而不是在 MLE 与先验中心之间任意作线性插值。椭圆形状和先验尺度改变时，折中的方向也会改变。




图 2.6 MLE 与 MAP 的参数几何。蓝色实线是以 $(2, 1)^T$ 为中心、两坐标尺度分别为 1 和 0.55 的高斯似然等高线；红色虚线是以原点为中心、尺度为 1.3 的各向同性高斯先验等高线。空心点为 MLE，黄色实心点为两项相加后的 MAP $(1.256, 0.848)^T$ 。该构造用于显示先验如何改变点估计，不代表 MAP 总在两中心的连线上。

若 $\mathbf{m}_0 = \mathbf{0}$ 、 $\mathbf{V}_0 = \tau^2 \mathbf{I}$ ，后验均值为 $(\mathbf{X}^T \mathbf{X} + \sigma^2 \mathbf{I} / \tau^2)^{-1} \mathbf{X}^T \mathbf{y}$ ，在本章归一化下对应 $\lambda = \sigma^2 / (n\tau^2)$ 的岭估计。高斯后验的均值与众数相同，所以也等于 MAP 估计。该对应要求截距处理一致：若先验惩罚全部特征系数，就不能直接与截距不受惩罚的岭模型比较。后验协方差与前面固定真参数下岭估计的重复抽样协方差也是不同对象。

有限维贝叶斯线性模型已经诱导出函数上的高斯分布：

$$\mathbf{m}_0(\mathbf{x}) = \boldsymbol{\phi}(\mathbf{x})^T \mathbf{m}_0, \quad k(\mathbf{x}, \mathbf{x}') = \boldsymbol{\phi}(\mathbf{x})^T \mathbf{V}_0 \boldsymbol{\phi}(\mathbf{x}').$$

任意有限个函数值都是高斯参数的线性变换，因此联合高斯。直接指定 $\mathbf{m}_0$ 和正定核 k ，便可越过显式系数建立函数先验。

定义 2.13 高斯过程 随机函数 f 称为高斯过程，若任意有限输入集合上的函数值向量均服从多元高斯分布。其均值函数为 $m_0(\mathbf{x})$ 、协方差函数为 $k(\mathbf{x}, \mathbf{x}')$ 时，记为 $f \sim \mathcal{GP}(m_0, k)$ 。

高斯过程允许有限秩核，因此并不必然对应无限维特征；有限维贝叶斯线性回归正是其中一个特例。对无限维核，也不需要先假设存在协方差为无限维单位矩阵的普通高斯权重向量，定义有限函数值的相容联合分布即可。

加入与函数独立的噪声 $y_i = f(\mathbf{x}_i) + \varepsilon_i$ ，其中 ε_i 相互独立且服从 $\mathcal{N}(0, \sigma^2)$ ， $\sigma^2 > 0$ 。令 $\mathbf{K}_{i,j} = k(\mathbf{x}_i, \mathbf{x}_j)$ ， $(\mathbf{k}_\star)_i = k(\mathbf{x}_i, \mathbf{x}_\star)$ ， $\mathbf{m}_0$ 表示训练点上的先验均值向量， $\mathbf{C} = \mathbf{K} + \sigma^2 \mathbf{I}$ ， $f_\star = f(\mathbf{x}_\star)$ 。联合分布为

$$\begin{pmatrix} \mathbf{y} \\ f_\star \end{pmatrix} \sim \mathcal{N} \left[\begin{pmatrix} \mathbf{m}_0 \\ m_0(\mathbf{x}_\star) \end{pmatrix}, \begin{pmatrix} \mathbf{C} & \mathbf{k}_\star \\ \mathbf{k}_\star^\top & k(\mathbf{x}_\star, \mathbf{x}_\star) \end{pmatrix} \right].$$

于是后验预测可以精确写成

$$\begin{aligned} \mu_\star &= m_0(\mathbf{x}_\star) + \mathbf{k}_\star^\top \mathbf{C}^{-1} (\mathbf{y} - \mathbf{m}_0), \\ v_\star &= k(\mathbf{x}_\star, \mathbf{x}_\star) - \mathbf{k}_\star^\top \mathbf{C}^{-1} \mathbf{k}_\star. \end{aligned} \quad (2.37)$$

为证明它，令 $Z = f_\star - m_0(\mathbf{x}_\star) - \mathbf{k}_\star^\top \mathbf{C}^{-1} (\mathbf{y} - \mathbf{m}_0)$ 。直接计算得到 $\text{Cov}(Z, \mathbf{y}) = \mathbf{0}$ ； Z 与 $\mathbf{y}$ 联合高斯，所以独立。其方差为 $v_\star$ ，从而条件于 $\mathbf{y}$ 时， $f_\star$ 的均值为 $\mu_\star$ 、方差为 $v_\star$ 。该方差非负也由它是随机变量方差得到。未来带噪声响应的方差则为 $v_\star + \sigma^2$ 。

核选择规定了先验中的相似性。平方指数核 $k(\mathbf{x}, \mathbf{x}') = \sigma_f^2 \exp(-\|\mathbf{x} - \mathbf{x}'\|_2^2 / (2\ell^2))$ 具有很强的平滑性，其中 $\sigma_f^2 > 0$ 是信号方差、 $\ell > 0$ 是长度尺度。Matérn 核可调节平滑程度，例如 $\nu = 3/2$ 时为 $\sigma_f^2 (1 + \sqrt{3}r/\ell) \exp(-\sqrt{3}r/\ell)$ ，其中 $r = \|\mathbf{x} - \mathbf{x}'\|_2$ ，对应一次均方可微的过程。一维周期核可写成 $\sigma_f^2 \exp(-2 \sin^2(\pi(x - x')/p)/\ell^2)$ ，表达周期 $p > 0$ 的相关结构。合法核的和与乘积仍合法，可以组合趋势与周期，但不保证所组合的结构符合实际数据。

图2.7展示了式(2.37)的两项输出。在这个固定平稳核的例子中，观测附近的函数值受到较强约束，观测间的较大空隙与远离观测的区域保留更多不确定性。曲线给出点预测，带状区域则说明在当前先验和噪声设定下，哪些函数值仍与数据相容。

2.4.1.2 参数学习

给定核和噪声参数时，后验已经由式(2.37)确定；仍需选择长度尺度、信号方差、噪声方差及可能的均值参数。令这些超参数为 θ ，把训练输入处的




图 2.7 高斯过程的后验均值与函数不确定性。六个点为构造观测；先验均值为零，平方指数核取 $\ell = 0.9$ 、 $\sigma_f = 1$ ，观测噪声标准差为 $\sigma = 0.18$ 。实线为 μ_* ，浅色带及虚线边界为 $\mu_* \pm 1.96\sqrt{v_*}$ ，表示潜在函数值的逐点约 95% 后验可信区间。它不是整条函数的同时可信带；预测未来带噪响应时，方差还须加 σ^2 。

潜在函数值积分掉，得到**边缘似然** (marginal likelihood)：在给定输入和超参数时，观测响应向量的概率密度。以下令先验均值为零：

$$\log p(\mathbf{y} | \mathbf{X}, \theta) = -\frac{1}{2} \mathbf{y}^\top \mathbf{C}_\theta^{-1} \mathbf{y} - \frac{1}{2} \log |\mathbf{C}_\theta| - \frac{n}{2} \log(2\pi). \quad (2.38)$$

二次项评价响应与协方差结构的匹配，行列式项来自密度归一化，两者共同决定目标。不能把“更复杂的核”机械等同于“行列式更大”，也不能由边缘似然推出自动找到正确结构或无需验证。

若 $\mathbf{a} = \mathbf{C}^{-1} \mathbf{y}$ ，固定零均值模型的梯度为

$$\frac{\partial \log p(\mathbf{y})}{\partial \theta_j} = \frac{1}{2} \text{tr} \left[(\mathbf{a} \mathbf{a}^\top - \mathbf{C}^{-1}) \frac{\partial \mathbf{C}}{\partial \theta_j} \right].$$

它来自 $d\mathbf{C}^{-1} = -\mathbf{C}^{-1}(d\mathbf{C})\mathbf{C}^{-1}$ 与 $d \log |\mathbf{C}| = \text{tr}(\mathbf{C}^{-1} d\mathbf{C})$ 。可以在正参数的对数坐标上使用梯度算法，多初值比较有助于发现不同局部最优；这种经验贝叶斯拟合通常仍把所选超参数当作固定值，因此没有保留全部超参数不确定性。

数值计算使用 Cholesky 分解 $\mathbf{C} = \mathbf{L}\mathbf{L}^\top$ 。解两次三角方程得到 $\mathbf{a}$ 后，预测均值为 $\mathbf{k}_*^\top \mathbf{a}$ ；令 $\mathbf{v} = \mathbf{L}^{-1} \mathbf{k}_*$ ，预测方差为 $k(\mathbf{x}_*, \mathbf{x}_*) - \|\mathbf{v}\|_2^2$ 。稠密分解需要 $O(n^3)$ 时间、 $O(n^2)$ 存储，预计算后的单点均值需 $O(n)$ 算术加核计算，单点方差通常需 $O(n^2)$ 三角求解。均值与方差不能统称同一个预测代价。

大数据下可选取 $m \ll n$ 个输入位置 $\mathbf{z}_j$ ，以潜在函数值 $u_j = f(\mathbf{z}_j)$ 作为**诱导变量** (inducing variables)，通过它们的近似后验概括数据对函数的

约束。Titsias 的变分诱导点方法在高斯回归中优化边缘对数似然的变分下界，以选择诱导输入并近似后验，常见稠密计算规模为 $O(nm^2)$ ；后续随机变分方法进一步支持小批量训练。近似是否充分，仍需检查诱导表示能否保留任务所需的函数变化³¹。

2.4.1.3 理论分析

GPR 内部的线性系统求解与样本增加时的后验收缩是两个层次的问题。固定设计、固定核和正噪声方差给出后验线性系统与正则化函数解的确定性最优性；明确回归抽样制度、真函数光滑性和先验尺度后，才可讨论渐近后验集中。这些结论不能推出经验贝叶斯超参数选择后的频率覆盖，也不能保证模型失配时的预测区间有效。

收敛性分析 固定核超参数与正噪声方差后，精确 GPR 通过正定线性系统求解后验，其计算误差来自线性系统的数值求解。若用迭代线性求解器替代矩阵分解，其收敛仍取决于矩阵条件数和算法；外层核超参数优化则可能是非凸的，不能沿用内部线性求解的保证。

后验均值还能解释为正则化核回归的最优解。为建立这一联系，回顾第1.2.1.2节的再生核 Hilbert 空间 (RKHS)：记核 k 对应的函数空间为 $\mathcal{H}_k$ ，其核截面满足 $f(\mathbf{x}) = \langle f, k(\mathbf{x}, \cdot) \rangle_{\mathcal{H}_k}$ 。这一再生关系把函数取值化为内积，也使核范数可以作为函数复杂度惩罚。

只要经验目标通过训练点取值依赖函数，范数惩罚就把最优解限制在训练点核截面的张成空间，这就是表示定理的核心。下面证明平方范数惩罚所需的形式，更一般的版本见相关文献³²。

定理 2.14 表示定理与核岭回归解 给定正定核 k 和 $\lambda > 0$ ，核岭回归问题

$$\min_{f \in \mathcal{H}_k} \frac{1}{2n} \sum_i (y_i - f(\mathbf{x}_i))^2 + \frac{\lambda}{2} \|f\|_{\mathcal{H}_k}^2$$

有唯一函数解

$$\hat{f}(\mathbf{x}) = \mathbf{k}_x^\top \boldsymbol{\alpha}_0, \quad \boldsymbol{\alpha}_0 = (\mathbf{K} + n\lambda \mathbf{I})^{-1} \mathbf{y},$$

其中 $(\mathbf{k}_x)_i = k(\mathbf{x}_i, \mathbf{x})$ 。核矩阵可以奇异；此时表示同一函数的系数向量未必唯一。

证明. 令 V 为有限个核截面 $k(\mathbf{x}_i, \cdot)$ 的张成空间，将任意 f 正交分解为 $f = f_{\parallel} + f_{\perp}$ 。由再生性质， $f_{\perp}(\mathbf{x}_i) = \langle f_{\perp}, k(\mathbf{x}_i, \cdot) \rangle = 0$ ，所以去掉 $f_{\perp}$ 不改变训练损失，而范数平方减少 $\|f_{\perp}\|^2$ 。因此任何最优解都属于 V ，可写为 $\sum_i \alpha_i k(\mathbf{x}_i, \cdot)$ 。

³¹ M. K. Titsias, *Variational Learning of Inducing Variables in Sparse Gaussian Processes* In Proceedings of the Twelfth International Conference on Artificial Intelligence and Statistics, 2009, pp. 567–574

³² B. Schölkopf, R. Herbrich, A. J. Smola, *A Generalized Representer Theorem* In Computational Learning Theory, 2001, pp. 416–426

在该表示下，目标为

$$\frac{1}{2n} \|\mathbf{y} - \mathbf{K}\boldsymbol{\alpha}\|_2^2 + \frac{\lambda}{2} \boldsymbol{\alpha}^\top \mathbf{K} \boldsymbol{\alpha}.$$

梯度条件是 $\mathbf{K}[(\mathbf{K} + n\lambda\mathbf{I})\boldsymbol{\alpha} - \mathbf{y}] = \mathbf{0}$ 。由于 $\mathbf{K} + n\lambda\mathbf{I} > 0$ ， $\boldsymbol{\alpha}_0$ 存在并满足此条件；凸性使它为全局最小点。这直接构造了原函数问题的解，无需约去可能奇异的 $\mathbf{K}$ 。函数范数平方的严格凸性保证函数解唯一。若 $\mathbf{v} \in \ker \mathbf{K}$ ，其对应函数范数平方为 $\mathbf{v}^\top \mathbf{K} \mathbf{v} = 0$ ，因此 $\boldsymbol{\alpha}_0 + \mathbf{v}$ 表示同一函数，说明系数可以不唯一。 ■

将 $\lambda = \sigma^2/n$ 代入该解，与式(2.37)的零均值后验预测完全一致。非零先验均值时，应对 $\mathbf{y} - \mathbf{m}_0$ 做相同核岭拟合，再加回 $\mathbf{m}_0(\mathbf{x})$ 。等价关系要求核尺度、均值和截距处理一致；若某个模型额外加入不受惩罚的截距，其解通常需要另解增广系统。

泛化分析 相同的点预测并不意味着全部推断对象相同。GP 方差是模型内潜在函数的后验不确定性，KRR 目标本身只确定一个函数估计；后者也可以配合频率学理论或校准构造区间。固定核超参数时，GP 后验方差只依赖输入与噪声设定，不直接依赖观测响应；输入间的相关性由核决定，不能简单归纳为“欧氏距离越远方差必然越大”。高斯可信区间在先验模型下有后验概率解释，模型失配或超参数估计后不自动具有同样的重复抽样覆盖率。

后验收缩研究样本增加时后验质量是否集中到真实函数附近。已有理论把收缩速度与先验函数落入小半径范数球的概率、真函数相对于 RKHS 的可逼近性及先验尺度联系起来。前一种概率称为小球概率，它衡量先验在局部函数邻域内分配了多少质量；固定设计与随机设计的结论还需分别说明所使用的函数距离³³。

例如，在 $\alpha > 0$ 阶光滑函数的非参数回归比较中，常见的 L^2 误差尺度为 $n^{-\alpha/(2\alpha+d)}$ ，其平方尺度则为 $n^{-2\alpha/(2\alpha+d)}$ 。某个 GP 先验能否达到这样的尺度，还取决于平滑度与先验尺度的匹配，以及具体观测设定和距离。后验收缩本身也不自动给出后验均值风险界或可信区间的频率覆盖保证。

³³ A. W. van der Vaart, J. H. van Zanten, *Rates of Contraction of Posterior Distributions Based on Gaussian Process Priors In The Annals of Statistics*, 2008, vol. 36, no. 3, pp. 1435–1463

2.4.1.4 支持非高斯似然（拉普拉斯近似与期望传播）

计数或二分类响应需要不同似然。仍可设潜在函数服从 GP，借助 $\exp(f)$ 或 logistic 函数映射到条件均值，但 $p(\mathbf{f} | \mathbf{y}) \propto p(\mathbf{y} | \mathbf{f})p(\mathbf{f})$ 一般不再是高斯，不能继续使用精确高斯回归公式。

拉普拉斯近似 (Laplace approximation) 在后验众数 $\hat{\mathbf{f}}$ 附近用二阶 Taylor 展开近似对数密度。若零均值先验的 $\mathbf{K}$ 正定，并在众数处定义 $\mathbf{W} =$

$-\nabla^2 \log p(\mathbf{y} | \mathbf{f})$, 后验局部高斯近似为

$$q(\mathbf{f}) = \mathcal{N}(\hat{\mathbf{f}}, (\mathbf{K}^{-1} + \mathbf{W})^{-1}),$$

前提是该精度矩阵正定。若核有限秩, 需在其有效子空间中计算; 不能直接写不存在的 $\mathbf{K}^{-1}$ 。多峰或强偏斜后验可能无法由一个局部高斯充分描述。

期望传播 (expectation propagation, EP) 用便于处理的近似因子替代逐个似然因子, 在移除当前近似因子后形成的分布上加入真实因子, 再匹配相应矩。它与拉普拉斯近似使用不同的局部信息, 不保证对所有问题都更准确或必然收敛。变分推断则通过优化分布族中的近似准则处理后验, 并可结合诱导变量。无论采用哪一种近似, 最终的观测预测仍需积分 $p(y_\star | f_\star)$; 潜在高斯的均值方差并不意味着观测响应也服从高斯³⁴。

³⁴ C. E. Rasmussen, C. K. I. Williams, *Gaussian Processes for Machine Learning*, MIT Press, 2006

2.4.1.5 小结

GPR 用核规定函数先验, 在高斯噪声下精确更新任意有限查询集合的分布。有限维贝叶斯线性模型、非线性核和非高斯似然都可在这一思路中理解, 但核选择、超参数估计与近似推断分别引入新的条件。计算瓶颈主要来自训练协方差矩阵; 只需点预测与还需完整方差时, 计算预算并不相同。

第5.4.2节的 GPLVM 复用 GP 核协方差和边缘似然计算, 却把低维输入坐标也作为未知量: GPR 已从观测输入预测数值响应, GPLVM 则从高维观测反求低维坐标并学习由低维空间到观测空间的映射。二者共享概率函数表示, 不共享任务方向与待估计对象。

2.4.2 模型对比与总结

贝叶斯线性回归与 GPR 的共同点是对函数不确定性进行更新, 区别主要在于表示方式与计算所依赖的规模变量。有限特征模型也可以通过非线性基表示曲线; GP 也可以使用有限秩核, 因此不能把两者简单分成“只能线性”和“必然无限维”。若显式基维数为 p , 贝叶斯线性回归的稠密训练通常需 $O(np^2 + p^3)$ 运算, 而一般稠密 GP 主要受 n 控制; 低秩表示可以在两种计算形式之间转换。

模型内后验区间在给定似然、先验和超参数处理下具有后验概率含义; 模型无关覆盖方法则把任意已训练回归器当作评分器, 在校准样本与测试样本可交换等条件下控制重复抽样覆盖。分割共形预测可以校准点预测的残差, 共形分位数回归 (conformalized quantile regression, CQR) 则保留上下分位点随输入变化的形状, 再用留出分数修正边际覆盖³⁵。第二卷“基础、理论和可信性”的“可靠性”章“可靠性的保证”节给出二者的构造、有限样本量词和条件覆盖边界。模型无关指有效性不要求基础回归器

³⁵ A. N. Angelopoulos, S. Bates, *A Gentle Introduction to Conformal Prediction and Distribution-Free Uncertainty Quantification* In arXiv preprint arXiv:2107.07511, 2022; Y. Romano, E. Patterson, E. J. Candès, *Conformalized Quantile Regression* In arXiv preprint arXiv:1905.03222, 2019

正确，不表示没有可交换性等数据条件；覆盖达标也不能替代区间宽度评价。

贝叶斯方法还能与其他模型结合。**贝叶斯加性回归树**（Bayesian additive regression trees, BART）对树之和及叶参数设置正则化先验，使用后验采样获得函数和预测分布，连接了本章的树路线与概率路线³⁶。

贝叶斯神经网络对网络权重设置先验；在特定独立权重先验、尺度和无限宽极限下，某些网络诱导的函数分布趋于 GP，并非任意网络结构或训练过程都具有这种极限。狄利克雷过程混合回归则对混合分布采用非参数先验，允许有效成分随数据变化；其优势在于表达多模态条件分布，成分解释与可识别性仍需检查。概率模型为决策提供分布信息，同时需要承担分布设定、后验计算与校准的成本。

³⁶ H. A. Chipman, E. I. George, R. E. McCulloch, *BART: Bayesian Additive Regression Trees* In The Annals of Applied Statistics, 2010, vol. 4, no. 1, pp. 266–298

2.5 基于集成的回归

第1.2.5节已给出 Bagging、Boosting 和 Stacking 的基本动机，第6章进一步说明成员怎样生成、依赖与组合。用于回归时，需要确定成员输出及组合后的预测对象：随机森林通常平均按平方损失训练的树预测；梯度提升的目标由所选回归损失决定；Stacking 则由元学习器按回归目标组合成员预测。平均条件均值预测不会自动得到条件分位数或覆盖区间，改变交付对象需要相应的训练或聚合规则。

比较树集成时，树深、树数、特征抽样、学习率和早停都应在训练流程中选择。袋外误差可以辅助诊断，仍不能替代最终测试；组合后也不能直接移植单棵树的剪枝最优性或独立叶平均证明。第二卷“基础、理论和可信性”的“二分类学习的可学习性”章“集成学习”节讨论投票与提升的学习理论，第6.1.3节讨论成员质量和错误依赖。实际选型应按表2.5中的预测对象比较误差、分布质量或区间覆盖，并同时记录训练与查询成本。

2.6 模型选择与评价

2.6.1 方法比较

回归方法可能估计条件均值、指定分位数或完整分布。表2.4把预测对象与函数表示、训练准则和区间解释放在一起比较；改变损失或概率设定，同一表示也可以服务于不同目标。

2.6.2 评价与选择

模型能输出什么，决定了评价应问什么。训练证据只说明候选模型怎样贴合训练目标，不能替代模型选择和最终测试；表2.5按输出类型固定训练、选择、独立校准和测试证据的职责。独立校准数据只供共形预测等需

代表方法	预测对象	函数表示	训练准则	推断或校准
OLS	条件均值	固定线性特征映射	平方损失	模型假设下的参数与预测区间
岭、Lasso	条件均值的受约束逼近	固定线性特征映射	平方损失加 ℓ_2 或 ℓ_1 系数惩罚	不自动给出区间, 需另加推断模型
分位数回归	指定条件分位数	线性特征映射	分位数损失	抽样假设下的分位数推断
SVR	容忍带点预测	线性特征或核展开	ϵ 不敏感损失加范数惩罚	不自带概率解释
GLM、GAM	经链接的条件均值	线性预测器或可加函数	似然或惩罚似然	响应模型假设下的参数与预测区间
分布回归	完整条件分布	各分布参数的线性或平滑函数	多参数似然或惩罚似然	模型内预测分布, 校准需样本外检查
k -NN、LOESS	局部条件均值	邻域常数或局部多项式	局部加权平方损失	不自动给出区间, 需另建推断或覆盖程序
CART	叶内均值、分位数或其他统计量	递归分区上的分段常数	分裂损失与复杂度惩罚	不自动给出有效区间
随机森林	条件均值; 变体可估计条件分位数	随机树的平均	单棵树的分裂损失	不自动给出有效区间
梯度提升	由损失确定的条件目标	基学习器的逐步加和	分阶段最小化经验风险	不自动给出有效区间
贝叶斯线性回归、GPR、BART	未来响应的后验预测	有限基、核函数或树之和	后验密度 (似然与先验)	参数或函数后验、模型内后验区间与后验预测分布

表 2.4 回归方法的属性导航。各行登记本章代表方法的基本形式，而不是划分互斥类别；改变损失、叶输出或概率设定后，同一函数表示可以对应不同预测对象。

要估计覆盖修正的方法使用，不能把它当作所有区间的必经步骤。完整分布的比较应使用**适当评分**（proper scoring rule），即在期望意义下鼓励报告真实分布的评分规则；对数得分与连续秩概率得分（continuous ranked probability score, CRPS）是常见选择。

输出类型	训练证据	选择证据	独立校准证据	测试证据
点均值	平方损失或均值模型似然	验证 MSE 选择表示与复杂度	不另设；若需覆盖则转入区间程序	独立测试 MSE、残差与分组误差
条件分位数	对应 τ 的分位数损失	验证分位数损失、尾部样本量与分位数交叉	不另设；原始分位点按其损失评价	测试分位数损失与经验超越率
模型内或参数化区间	拟合区间所需的响应或后验模型	验证集选择模型与超参数	不需要独立校准；区间由已拟合模型构造	测试覆盖率、宽度及分组表现
共形覆盖区间	训练折拟合基础预测器或端点	校准前选定基础模型与超参数	独立校准集估计不合格分位数	测试覆盖率、宽度及分组表现
完整分布	似然、对数得分或其他适当评分	验证适当评分及分布诊断	通常不另设；再校准时单独留出	测试对数得分或 CRPS、校准与锐度

表 2.5 不同回归输出的评价协议。模型内或参数化区间依赖其响应模型、抽样假设或后验设定；共形覆盖区间才用独立校准样本估计覆盖修正。测试数据始终留到选择与校准结束之后。

适当评分怎样连接概率预测、估计与模型选择，可参见 Gneiting 与 Raftery 的统一讨论³⁷。以章首房价任务为例，可以先把成交记录按部署时间或地区规则划分，再在每个训练折内完成缺失值处理、标准化、特征选择和模型拟合，用验证结果选择线性、局部、树或概率表示及其超参数。随后检查残差随面积、地区和价格水平的变化，形成模型失配与区间宽度的诊断。若交付共形覆盖区间，还要在模型与超参数冻结后，用未参与拟合和选择的校准集确定覆盖修正；模型内或参数化区间不因此强制另留校准集。完成这些步骤后，才在独立测试集上按表2.5报告与交付对象匹配的误差、覆盖或分布评分。若看过测试结果后再改模型，该批数据就不再是最终测试证据。

选型时先由决策问题确定输出：只需平均成本时比较条件均值风险，关心阈值超越时估计相应分位数，需要完整风险积分时才承担分布建模成本。若要求模型无关的有限样本覆盖承诺，再为分割共形或 CQR 留出独立校准数据；若采用模型内后验区间或参数化频率学区间，则按各自假设构造，并在独立测试数据上检查覆盖与宽度。随后用残差结构判断表示：近似全局关系优先从线性或可加模型开始，局部平滑关系比较邻域方法，明显阈值和交互比较树及其集成；最后在同一验证协议下权衡误差、校准、时间、存储和解释需求。显式线性模型可把训练信息压缩为固定系数，局部方法要保留查询库，核与集成方法则取决于展开规模、树数及是否计算分布信息。

³⁷ T. Gneiting, A. E. Raftery, *Strictly Proper Scoring Rules, Prediction, and Estimation* In Journal of the American Statistical Association, 2007, vol. 102, no. 477, pp. 359–378

2.7 本章小结

回到房价预测，平方损失估计条件均值，分位数损失估计预算阈值，概率模型描述价格分布。线性与核、邻域、树与规则给出不同函数表示，集成组合成员预测；输出目标和表示方式要一起选择。

有限数据下，模型的灵活性受到样本量、特征结构与计算成本限制。未来响应的噪声、函数估计不确定性和区间覆盖是不同对象，须按模型假设与样本外证据分别解释；求解充分也不保证预测准确。第2.6节据此比较误差、区间、分布评分与资源成本。

第3章把数值响应换成类别标签，仍使用线性与核、近邻、分区和概率模型；任务改变后，输出、损失、邻域聚合与决策规则也随之改变。

分类

判断邮件是否为垃圾邮件，需要从预设类别中作出选择。**分类** (classification) 从带标签样本学习这种决策。设 $D_n = \{(\mathbf{x}_i, y_i)\}_{i=1}^n$, $\mathbf{x}_i \in \mathbb{R}^d$, $y_i \in \{1, \dots, C\}$, 分类器为 $f: \mathbb{R}^d \rightarrow \{1, \dots, C\}$; 预测类别发生变化的位置构成**决策边界** (decision boundary)。本章讨论每个样本属于一个预设类别的单标签分类。

1930 年代的 Fisher 判别分析从投影区分类别，1950 年代的感知机通过错分反馈学习边界。决策树在 1980 年代形成系统方法，1990 年代的支持向量机把间隔与核方法结合起来，此后的树集成进一步提高了复杂数据上的预测能力¹。

在高维稀疏文本等任务中，线性分类器与朴素贝叶斯仍便于建立基线；在异质表格数据上，随机森林与梯度提升树是常用候选，需要与其他方法在相同预算下比较²。本章按线性关系、邻域、树与规则、概率和集成展开：它们分别学习得分、聚合局部标签、使用条件分支、估计类别概率或组合成员；半监督分类随后说明怎样利用未标注样本。

除特别说明外，统计分析假设训练样本独立同分布，新样本独立来自同一分布。零一损失风险记为 $R(f) = \mathbb{P}(f(\mathbf{x}) \neq y)$ ，所有可测分类规则的最小风险记为 R^* ，即贝叶斯风险；其学习理论基础见第二卷“基础、理论和可信性”的“二分类学习的可学习性”章。

3.1 基于线性关系的分类

第1.2.1节的线性得分在分类中用于比较类别。本节从 LDA、感知机和 SVM 考察三种学习依据：类统计量、分类错误反馈和间隔。相同的线性边界可以来自不同准则；随后用简介已建立的核方法扩展 SVM 的特征空间。

LDA 兼有投影与概率解释，本节推导其共享协方差形式，第3.4节再从 GDA 模型族说明一般协方差设定。Fisher 投影的统计量、感知机的可分性条件与软间隔 SVM 的误差容忍约束不同对象，不能排成假设强度依次递减的序列。

¹ R. A. Fisher, *The Use of Multiple Measurements in Taxonomic Problems* In *Annals of Eugenics*, 1936, vol. 7, no. 2, pp. 179–188; F. Rosenblatt, *The Perceptron: A Probabilistic Model for Information Storage and Organization in the Brain* In *Psychological Review*, 1958, vol. 65, no. 6, pp. 386–408; C. Cortes, V. Vapnik, *Support-Vector Networks* In *Machine Learning*, 1995, vol. 20, no. 3, pp. 273–297

² N. Erickson, L. Purucker, A. Tschalzev, D. Holzmüller, P. Mutalik Desai, D. Salinas, F. Hutter, *TabArena: A Living Benchmark for Machine Learning on Tabular Data* In *Advances in Neural Information Processing Systems*, 2026, vol. 38

3.1.1 线性判别分析 (LDA)

如果用一个线性得分区分类别，怎样确定各特征的权重和分类阈值？一种办法是先描述每一类样本在空间中的分布，再比较新样本来自各类的可能性。**线性判别分析** (linear discriminant analysis, LDA) 在高斯生成模型下采用这条路线：估计类均值、共享协方差和类先验，再由贝叶斯法则得到线性判别函数。

LDA 还有一个几何起点。Fisher 在 1936 年的鸢尾花分类研究中寻找一种线性组合，使两类均值的差异相对于类内波动尽可能大。这一准则不求样本服从高斯分布；它与高斯生成模型可以给出相同的判别方向，但概率解释和适用条件有所不同³。

从两类的线性组合转向多个总体的判别，问题不再只是选择一条轴，还包括需要保留多少个方向。Rao 在 1948 年系统讨论了多总体的生物分类与判别表示，这也为理解 LDA 如何从分类规则延伸为有监督降维方法提供了历史背景⁴。

3.1.1.1 模型结构

沿用训练集 $D_n = \{(\mathbf{x}_i, y_i)\}_{i=1}^n$ ，其中 $\mathbf{x}_i \in \mathbb{R}^d$ 、 $y_i \in \{1, \dots, C\}$ 。生成式 LDA 假设

$$\mathbb{P}(y = c) = \pi_c, \quad \pi_c > 0, \quad \sum_{c=1}^C \pi_c = 1, \quad (3.1)$$

$$p(\mathbf{x} | y = c) = \mathcal{N}(\mathbf{x}; \boldsymbol{\mu}_c, \boldsymbol{\Sigma}), \quad \boldsymbol{\Sigma} > 0.$$

这里 $\boldsymbol{\mu}_c \in \mathbb{R}^d$ 描述第 c 类的中心， $\boldsymbol{\Sigma} \in \mathbb{R}^{d \times d}$ 描述类内各方向的波动及特征之间的相关性。共享协方差意味着各类可以有不同中心，但在中心附近具有相同的椭球形状和朝向；并不要求各个特征相互独立。

在零一损失下，应选择后验概率最大的类别。取对数并展开高斯密度，有

$$\begin{aligned} \log\{\pi_c p(\mathbf{x} | y = c)\} &= a(\mathbf{x}) + \delta_c(\mathbf{x}), \\ \delta_c(\mathbf{x}) &= \mathbf{x}^\top \boldsymbol{\Sigma}^{-1} \boldsymbol{\mu}_c \\ &\quad - \frac{1}{2} \boldsymbol{\mu}_c^\top \boldsymbol{\Sigma}^{-1} \boldsymbol{\mu}_c + \log \pi_c. \end{aligned} \quad (3.2)$$

其中 $a(\mathbf{x})$ 收集了 $-\mathbf{x}^\top \boldsymbol{\Sigma}^{-1} \mathbf{x}/2$ 、对数行列式和高斯归一化常数，均与类别无关。正是共享协方差使二次项在类别比较时抵消，留下关于 $\mathbf{x}$ 的仿射函数。任意两类得分相等的位置通常为超平面；多分类时，各类别区域由若干这样的比较共同确定，而不是全体类别只共用一个分割面。

³ R. A. Fisher, *The Use of Multiple Measurements in Taxonomic Problems* In *Annals of Eugenics*, 1936, vol. 7, no. 2, pp. 179–188

⁴ C. R. Rao, *The Utilization of Multiple Measurements in Problems of Biological Classification* In *Journal of the Royal Statistical Society: Series B (Methodological)*, 1948, vol. 10, no. 2, pp. 159–193

训练后把估计参数代入 δ_c ，得到 $\hat{\delta}_c$ 。预测规则及相应的模型后验为

$$\begin{aligned} \hat{f}_{\text{LDA}}(\mathbf{x}) &= \arg \max_{c \in \{1, \dots, C\}} \hat{\delta}_c(\mathbf{x}), \\ \hat{p}_c(\mathbf{x}) &= \frac{\exp\{\hat{\delta}_c(\mathbf{x})\}}{\sum_{j=1}^C \exp\{\hat{\delta}_j(\mathbf{x})\}}. \end{aligned} \quad (3.3)$$

本节对 $\arg \max$ 的平局统一选择索引最小的类别。若放宽共享协方差约束，让每类使用自己的 Σ_c ，二次项便不再普遍抵消，得到**二次判别分析** (quadratic discriminant analysis, QDA)，即允许二次决策边界的高斯分类器⁵。

3.1.1.2 参数学习

生成模型的最大似然估计 有标签样本已经给出了每个观测所属的高斯分量，因此这里不需要推断类别归属。令 $n_c = \sum_{i=1}^n \mathbb{1}\{y_i = c\}$ ，暂设各类都有样本。忽略与参数无关的常数，对数似然为

$$\begin{aligned} \ell &= \sum_{c=1}^C n_c \log \pi_c - \frac{n}{2} \log \det \Sigma \\ &\quad - \frac{1}{2} \sum_{c=1}^C \sum_{i: y_i=c} (\mathbf{x}_i - \boldsymbol{\mu}_c)^\top \Sigma^{-1} (\mathbf{x}_i - \boldsymbol{\mu}_c). \end{aligned} \quad (3.4)$$

对先验加入约束 $\sum_c \pi_c = 1$ ，拉格朗日驻点给出 n_c/π_c 为同一常数；归一化后该常数为 n 。对 $\boldsymbol{\mu}_c$ 求导，则有 $\Sigma^{-1} \sum_{i: y_i=c} (\mathbf{x}_i - \boldsymbol{\mu}_c) = \mathbf{0}$ 。由此得到

$$\hat{\pi}_c = \frac{n_c}{n}, \quad \hat{\boldsymbol{\mu}}_c = \frac{1}{n_c} \sum_{i: y_i=c} \mathbf{x}_i. \quad (3.5)$$

这两个估计分别是类别出现频率和该类的样本均值。

把均值代回似然，定义**类内散度矩阵** (within-class scatter matrix)

$$\mathbf{S}_W = \sum_{c=1}^C \sum_{i: y_i=c} (\mathbf{x}_i - \hat{\boldsymbol{\mu}}_c)(\mathbf{x}_i - \hat{\boldsymbol{\mu}}_c)^\top. \quad (3.6)$$

它累加每个样本相对于本类中心的偏离。用精度矩阵 $\boldsymbol{\Omega} = \Sigma^{-1}$ 改写剩余目标，得到 $n \log \det \boldsymbol{\Omega} / 2 - \text{tr}(\boldsymbol{\Omega} \mathbf{S}_W) / 2$ 。其驻点满足 $n \boldsymbol{\Omega}^{-1} = \mathbf{S}_W$ ，故当 $\mathbf{S}_W > 0$ 时，

$$\hat{\Sigma} = \frac{1}{n} \mathbf{S}_W. \quad (3.7)$$

对 $\boldsymbol{\Omega}$ 的目标是严格凹的，因此该驻点给出最大似然解。

式(3.7)的分母是 n ，不是 $n - C$ 。这种合并各类类内变动的估计称为**合**

⁵ T. Hastie, R. Tibshirani, J. Friedman, *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*, Springer, 2009, 2nd ed.

并协方差 (pooled covariance), 其无偏形式为

$$\hat{\Sigma}_U = \frac{S_W}{n - C}, \quad n > C.$$

在共享协方差假设下, 给定各类样本数, 有 $E[S_W | y_1, \dots, y_n] = (n - C)\Sigma$, 因为估计每个类中心各消耗一个自由度。最大似然与无偏估计是不同准则; 两种估计渐近相同, 但有限样本下有所区别。特别是先验不等时, 整体缩放协方差会改变几何得分相对于 $\log \hat{\pi}_c$ 的权重, 预测边界未必相同。

闭式估计不等于没有计算代价。对稠密数据, 累积类内散度需要 $O(nd^2)$ 运算, 矩阵分解需要 $O(d^3)$ 运算。实现时分解一次 $\hat{\Sigma}$, 再解 C 个线性方程组 $\hat{\Sigma}a_c = \hat{\mu}_c$, 预存 a_c 和常数得分项; 不必显式求逆, 预测一个样本只需 $O(Cd)$ 运算。若 S_W 奇异, 正定参数域内上述最大似然解并不存在, 需要降低维数或作正则化, 不能直接使用逆矩阵公式。

Fisher 投影的学习 生成模型之外, 还可以直接比较投影后的类间分离与类内波动。令总样本均值 $\hat{\mu} = \sum_c (n_c/n)\hat{\mu}_c$, 定义**类间散度矩阵** (between-class scatter matrix)

$$S_B = \sum_{c=1}^C n_c (\hat{\mu}_c - \hat{\mu})(\hat{\mu}_c - \hat{\mu})^\top.$$

它衡量各类中心相对于总中心的分散程度。投影到方向 w 后, 两种散度分别变为 $w^\top S_B w$ 和 $w^\top S_W w$ 。**Fisher 判别准则** (Fisher discriminant criterion) 取两者之比。以下假设 $S_W > 0$, 使每个非零方向的分母都为正:

$$J(w) = \frac{w^\top S_B w}{w^\top S_W w}, \quad w \neq 0. \quad (3.8)$$

分子鼓励类中心远离, 分母抑制同类样本投影后过于分散。

图 3.1 固定同一组二维教学样本, 只改变投影方向。沿 $w_A = (1, 0)^\top$, 两类投影均值相差 2, 而各类仅在宽度 0.6 的区间内波动; 沿 $w_B = (3/5, 4/5)^\top$, 均值差缩为 1.2, 同类投影却散布得更宽, 异类点在数轴上交错。由图注中的构造可算得 $S_W = \text{diag}(2/5, 8)$ 、 $S_B = \text{diag}(8, 0)$, 所以 $J(w_A) = 20$, $J(w_B) = 180/329$ 。这个比较衡量的是同一批样本投影后的相对分离程度, 不是测试错误率。

由于 J 不受 w 的非零倍数缩放影响, 可以约束 $w^\top S_W w = 1$ 。对 $w^\top S_B w - \lambda(w^\top S_W w - 1)$ 求导, 得到**广义特征值问题** (generalized eigenvalue problem):

$$S_B w = \lambda S_W w. \quad (3.9)$$



(A) 方向 w_A : 投影后分离(B) 方向 w_B : 投影后交错

图 3.1 同一点集在两个单位方向上的投影。两类各有 4 点，中心分别为 $(-1, 0)^T$ 、 $(1, 0)^T$ ，都加上偏移 $(-0.3, -1)^T$ 、 $(-0.1, 1)^T$ 、 $(0.1, 1)^T$ 、 $(0.3, -1)^T$ ；这是人为构造，坐标无量纲。两行只改变黄色投影方向： $w_A = (1, 0)^T$ 与 $w_B = (3/5, 4/5)^T$ 。右侧按 $z = w^T x$ 把蓝圆和红方放到同一数轴，彩色短竖线标出各类投影均值；两行共用数轴尺度。

驻点还需比较大小。令 $\mathbf{v} = \mathbf{S}_W^{1/2} \mathbf{w}$, 则

$$J(\mathbf{w}) = \frac{\mathbf{v}^\top \mathbf{A} \mathbf{v}}{\mathbf{v}^\top \mathbf{v}}, \quad \mathbf{A} = \mathbf{S}_W^{-1/2} \mathbf{S}_B \mathbf{S}_W^{-1/2}.$$

把 $\mathbf{v}$ 展开到对称半正定矩阵 $\mathbf{A}$ 的正交特征向量上, 上式就是各特征值的加权平均, 权重非负且总和为 1。最大值因而是最大特征值; 取对应特征向量, 再乘 $\mathbf{S}_W^{-1/2}$, 便得到最优 Fisher 方向。若最大特征值有重数, 最优方向未必唯一。

二分类时, 令 $\mathbf{h} = \hat{\boldsymbol{\mu}}_1 - \hat{\boldsymbol{\mu}}_2 \neq \mathbf{0}$, 由总均值的定义可得

$$\mathbf{S}_B = \frac{n_1 n_2}{n} \mathbf{h} \mathbf{h}^\top, \quad \mathbf{w}_F \propto \mathbf{S}_W^{-1} \mathbf{h}.$$

生成式 LDA 的法向量则为 $\mathbf{w}_G = \hat{\boldsymbol{\Sigma}}^{-1} \mathbf{h} = n \mathbf{S}_W^{-1} \mathbf{h}$, 两者方向相同。但完整的生成式分类规则还比较

$$\hat{\delta}_1(\mathbf{x}) - \hat{\delta}_2(\mathbf{x}) = \mathbf{w}_G^\top \left(\mathbf{x} - \frac{\hat{\boldsymbol{\mu}}_1 + \hat{\boldsymbol{\mu}}_2}{2} \right) + \log \frac{\hat{\pi}_1}{\hat{\pi}_2} \quad (3.10)$$

的正负。Fisher 准则本身只给方向, 不给类先验、后验概率或这一阈值。两类均值相同时, 均值散度准则没有正特征值方向, 而生成模型仍可按先验选择类别。由此可见, 非高斯数据上仍能使用 Fisher 投影, 但不能据此沿用高斯 LDA 的贝叶斯最优性结论。

3.1.1.3 理论分析

收敛性分析 生成式 LDA 的均值、先验与协方差都有闭式估计, 因此这里考察的是样本量增加时估计是否趋近真实参数, 而不是某个迭代过程何时停止。**一致性** (consistency) 正是这种渐近性质; 它不表示某个有限训练集上的估计已经准确。

定理 3.1 LDA 参数估计的一致性 设 d 和 C 固定, 训练样本独立同分布, 真实分布满足式 (3.1), 且所有 $\pi_c^* > 0$ 、 $\boldsymbol{\Sigma}^* > \mathbf{0}$ 。当 $n \rightarrow \infty$ 时,

$$\hat{\pi}_c \xrightarrow{\mathbb{P}} \pi_c^*, \quad \hat{\boldsymbol{\mu}}_c \xrightarrow{\mathbb{P}} \boldsymbol{\mu}_c^*, \quad \hat{\boldsymbol{\Sigma}} \xrightarrow{\mathbb{P}} \boldsymbol{\Sigma}^*.$$

所有类别非空且 $\hat{\boldsymbol{\Sigma}}$ 正定的概率趋于 1。

证明. 为处理随机的 n_c , 把类均值写成两个全样本平均之比:

$$\hat{\boldsymbol{\mu}}_c = \frac{n^{-1} \sum_{i=1}^n \mathbf{x}_i \mathbb{1}\{y_i = c\}}{n^{-1} \sum_{i=1}^n \mathbb{1}\{y_i = c\}}.$$

大数定律使分母收敛到 $\pi_c^* > 0$, 分子收敛到 $\pi_c^* \boldsymbol{\mu}_c^*$, 因而先验和均值都一

致。尚未观察到某一类时可以任意约定其均值；该事件的概率趋于零，不影响结论。

共享协方差估计可展开为

$$\hat{\Sigma} = \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i \mathbf{x}_i^\top - \sum_{c=1}^C \hat{\pi}_c \hat{\mu}_c \hat{\mu}_c^\top.$$

高斯分布有有限二阶矩，故第一项收敛到

$$\mathbb{E}[\mathbf{x} \mathbf{x}^\top] = \Sigma^* + \sum_{c=1}^C \pi_c^* \mu_c^* (\mu_c^*)^\top.$$

第二项消去类中心对二阶矩的贡献，余下 Σ^* 。固定维数下，矩阵逐元素收敛也给出算子范数收敛；由 Σ^* 的最小特征值严格为正，估计矩阵以趋于 1 的概率可逆。上述步骤实际上可由强大数定律加强为几乎必然收敛。■

矩阵求逆和 $\log \pi_c$ 在这些条件下连续，所以在参数几乎必然收敛的事件上，对每个固定输入 $\mathbf{x}$ ，有 $\hat{\delta}_c(\mathbf{x}) \rightarrow \delta_c^*(\mathbf{x})$ 。但 $\arg \max$ 在平局处不连续：在真实最大得分唯一的输入处，估计类别最终等于该输入的唯一贝叶斯类别；平局处则未必如此。若最优类别平局的输入集合概率为零，就能进一步推出随机输入上的预测标签收敛。不同贝叶斯分类器在平局处可以选择不同标签，却有相同风险。

泛化分析 参数趋近真实值以后，还需要说明这如何影响独立测试样本上的错误率。分类风险的一致性不要求标签处处收敛。记 $p_c^*(\mathbf{x})$ 为真实后验， f^* 任选一个贝叶斯规则。由于 $\hat{f}_{\text{LDA}}$ 最大化 $\hat{p}_c$ ，逐点有

$$\begin{aligned} 0 &\leq p_{f^*(\mathbf{x})}^*(\mathbf{x}) - p_{\hat{f}_{\text{LDA}}(\mathbf{x})}^*(\mathbf{x}) \\ &\leq 2 \max_{1 \leq c \leq C} |\hat{p}_c(\mathbf{x}) - p_c^*(\mathbf{x})|. \end{aligned} \quad (3.11)$$

这个上界来自在两项之间分别加减相应的估计后验，并利用 $\hat{p}_{\hat{f}_{\text{LDA}}} \geq \hat{p}_{f^*}$ 。在参数几乎必然收敛的事件上，后验估计也对每个输入收敛；右端趋于零且不超过 2。对与训练集独立、来自同一分布的测试输入积分，再用支配收敛定理，得到

$$R(\hat{f}_{\text{LDA}} | D_n) \longrightarrow R^* \quad \text{几乎必然,}$$

其中 $R(\hat{f}_{\text{LDA}} | D_n)$ 是给定训练集后的测试错误率， R^* 是贝叶斯错误率。有限样本中无法拟合时可暂用任意固定分类器，不改变这一渐近结论。这是模型正确指定、固定维数下的保证，不是对任意分布或 d 随 n 快速增长的普遍保证，也未给出有限样本的收敛速率。Fisher 准则在当前训练集上取得最大值，不能替代这一风险分析。

3.1.1.4 支持有监督降维

如果类别多于两个,一条投影轴可能不足以保留类中心之间的差异。把多个广义特征向量作为 $\mathbf{W} \in \mathbb{R}^{d \times r}$ 的列, 就可以把输入转换为 $\mathbf{z} = \mathbf{W}^\top(\mathbf{x} - \hat{\boldsymbol{\mu}}) \in \mathbb{R}^r$ 。以下仍假设 $\mathbf{S}_W > 0$, 并取 $1 \leq r \leq d$ 。

为避免重复选择同一方向, 可要求不同投影轴在类内散度度量下正交:

$$\max_{\mathbf{W}} \text{tr}(\mathbf{W}^\top \mathbf{S}_B \mathbf{W}) \quad \text{满足} \quad \mathbf{W}^\top \mathbf{S}_W \mathbf{W} = \mathbf{I}_r. \quad (3.12)$$

在前述白化坐标中, 该问题选择 $\mathbf{A}$ 最大的 r 个特征值对应的正交方向, 因而也就是式 (3.9) 中最大的 r 个广义特征值方向。

为什么有用的方向至多为 $C-1$ 个? 令 $\mathbf{M} \in \mathbb{R}^{d \times C}$ 的第 c 列为 $\sqrt{n_c}(\hat{\boldsymbol{\mu}}_c - \hat{\boldsymbol{\mu}})$, 则

$$\mathbf{S}_B = \mathbf{M} \mathbf{M}^\top, \quad \mathbf{M} \begin{pmatrix} \sqrt{n_1} \\ \vdots \\ \sqrt{n_C} \end{pmatrix} = \mathbf{0}.$$

右侧列向量非零, 说明 $\mathbf{M}$ 的 C 列线性相关。因此 $\text{rank}(\mathbf{S}_B) \leq \min(d, C-1)$; 可逆白化不改变秩, $\mathbf{A}$ 也至多有这么多个正特征值。若类中心还有额外的线性依赖, 实际维数更低。这个限制针对类均值散度, 不表示任意分类任务的全部信息都能无损压缩到 $C-1$ 维; 例如均值相同而协方差不同的类别, 可能被该准则忽略。

LDA 投影使用了标签, 因此训练和验证时必须把它作为学习流程的一部分, 在每个训练划分内重新估计投影, 不能先用全体样本标签降维再评估。得到的低维特征可以交给近邻分类器等后续模型。第5章按保留信息的目标比较降维方法; 其中第5.1.1节的 PCA 保留输入方差而不使用类别标签, LDA 则保留类别均值相对于类内波动的判别信息。Fisherfaces 人脸识别方法就是借助 Fisher 准则构造低维判别表示的一个具体例子⁶。

3.1.1.5 小结

LDA 给线性得分提供了两种解释: 共享协方差高斯模型给出概率、方向和阈值, Fisher 准则则直接选择类中心相对分离的投影。两者在二分类且采用同一类内散度时给出相同方向, 但概率解释和风险保证仍依赖额外假设。作为特征变换, LDA 也用于语音识别; 例如 Haeb-Umbach 与 Ney 研究了按语音类别学习线性变换, 再与后续识别模型结合的方案⁷。

选用 LDA 时, 需要同时考察分布近似和协方差的可估计性。偏离高斯不必然使分类失效, 却使前述最优性证明不再适用; 异常样本也会影响均值与协方差。由于 $\text{rank}(\mathbf{S}_W) \leq \min(d, n-C)$, 当 $n-C < d$ 时估计必然奇异, 即使样本稍多于这个界也可能不稳定。降维或收缩协方差可以改善可计算性, 但引入了新的选择及偏差, 需要用独立验证评估。

⁶ P. N. Belhumeur, J. P. Hespanha, D. J. Kriegman, *Eigenfaces vs. Fisherfaces: Recognition Using Class Specific Linear Projection* In IEEE Transactions on Pattern Analysis and Machine Intelligence, 1997, vol. 19, no. 7, pp. 711–720

⁷ R. Haeb-Umbach, H. Ney, *Linear Discriminant Analysis for Improved Large Vocabulary Continuous Speech Recognition* In Proceedings of the IEEE International Conference on Acoustics, Speech, and Signal Processing, 1992, pp. 13–16

3.1.2 感知机

如果不估计类条件分布，能否直接根据分类结果调整边界？**感知机**（perceptron）的做法是用线性得分预测类别，遇到错误就修正权重。它不要求高斯分布；线性可分性是其有限次更新保证的条件，而不是运行算法的前提。Rosenblatt 在 1958 年的论文中研究了感知机的学习机制，本节介绍的是其中广泛使用的线性阈值模型与误差修正规则⁸。

这条研究路线也有硬件实现。康奈尔航空实验室建造的 Mark I Perceptron 将感知机思想实现为电子装置，但历史上的系统还包含感觉、关联和响应等组织，不能把它的全部结构等同于今天的单个线性分类器⁹。

⁸ F. Rosenblatt, *The Perceptron: A Probabilistic Model for Information Storage and Organization in the Brain* In *Psychological Review*, 1958, vol. 65, no. 6, pp. 386–408

⁹ National Museum of American History, *Electronic Neural Network, Mark I Perceptron*, Smithsonian Institution, URL: https://americanhistory.si.edu/collections/object/nmah_334414 (visited on 10/02/2026)

3.1.2.1 模型结构

本小节先使用二分类标签 $y_i \in \{-1, +1\}$ 。为了使偏置在更新规则和收敛证明中始终处于同一坐标系，引入**增广向量**（augmented vector），即在输入末尾补一个恒为 1 的分量，并把偏置并入参数：

$$\tilde{\mathbf{x}} = \begin{pmatrix} \mathbf{x} \\ 1 \end{pmatrix}, \quad \tilde{\mathbf{w}} = \begin{pmatrix} \mathbf{w} \\ b \end{pmatrix} \in \mathbb{R}^{d+1}. \quad (3.13)$$

其中 $\mathbf{w} \in \mathbb{R}^d$, $b \in \mathbb{R}$ 。分类规则为

$$f(\mathbf{x}) = \text{sign}(\tilde{\mathbf{w}}^\top \tilde{\mathbf{x}}) = \text{sign}(\mathbf{w}^\top \mathbf{x} + b). \quad (3.14)$$

约定 $\text{sign}(s) = +1$ 当 $s \geq 0$ ，否则为 -1 。非退化边界 $\mathbf{w}^\top \mathbf{x} + b = 0$ 是在 d 维输入空间中的 $(d-1)$ 维超平面。它与二分类 LDA 具有相同的边界形式，但其参数不由类分布及先验推出，也不自动给出类别概率。

在这一表示下，正间隔可分是指存在单位向量 $\mathbf{u}^* \in \mathbb{R}^{d+1}$ 和 $\gamma > 0$ ，使

$$\begin{aligned} y_i \langle \mathbf{u}^*, \tilde{\mathbf{x}}_i \rangle &\geq \gamma, & i = 1, \dots, n, \\ \|\mathbf{u}^*\|_2 &= 1, & \|\tilde{\mathbf{x}}_i\|_2 \leq R. \end{aligned} \quad (3.15)$$

这里 R 约束的是增广输入，因此 $R \geq \max_i \sqrt{\|\mathbf{x}_i\|_2^2 + 1}$ 。 γ 也是增广空间中的间隔；若 $\mathbf{u}^* = (\mathbf{v}^\top, a)^\top / \sqrt{\|\mathbf{v}\|_2^2 + a^2}$ ，其分母包含偏置 a ，不同于原输入空间中以 $\|\mathbf{v}\|_2$ 归一化的几何距离。有限训练集只要能被仿射超平面严格分开，就存在这样的正 γ 。

线性表示的边界也很具体。例如异或任务把 $(0, 0)$ 、 $(1, 1)$ 标为负类，把 $(1, 0)$ 、 $(0, 1)$ 标为正类。按上述平局规则，前两点要求 $b < 0$ 和 $w_1 + w_2 + b < 0$ ，后两点要求 $w_1 + b \geq 0$ 和 $w_2 + b \geq 0$ 。前两式相加与后两式相加，对同一个 $w_1 + w_2 + 2b$ 给出矛盾要求。Minsky 与 Papert 在 1969 年的《Perceptrons》中系统研究了此类表示能力限制；改变输入特征或加入非线性隐藏层可以

越过单个线性边界的限制，但那已经改变了模型族¹⁰。

¹⁰ M. Minsky, S. Papert, *Perceptrons: An Introduction to Computational Geometry*, MIT Press, 1969

3.1.2.2 参数学习

从 $\tilde{\mathbf{w}}^{(0)} = \mathbf{0}$ 出发，若当前样本满足 $y_i \langle \tilde{\mathbf{w}}^{(t)}, \tilde{\mathbf{x}}_i \rangle \leq 0$ ，便进行一次更新：

$$\tilde{\mathbf{w}}^{(t+1)} = \tilde{\mathbf{w}}^{(t)} + \eta y_i \tilde{\mathbf{x}}_i, \quad \eta > 0. \quad (3.16)$$

这里 t 只数实际更新，学习率 η 保持不变。拆开最后一个分量，就是 $\mathbf{w} \leftarrow \mathbf{w} + \eta y_i \mathbf{x}_i$ 和 $b \leftarrow b + \eta y_i$ 。同一个样本的有符号得分增加 $\eta \|\tilde{\mathbf{x}}_i\|_2^2$ ，所以更新确实朝修正当前判断的方向移动；但它可能同时破坏其他样本的正确分类，因而需要反复遍历。零得分也触发更新，即使按平局规则恰好预测为正确的正类，仍要求它离开边界。

算法 3.1 带遍历上限的感知机训练

输入： D_n ，固定学习率 $\eta > 0$ ，最大遍历轮数 $E \geq 1$

输出： 参数 $\tilde{\mathbf{w}}$ 与是否已验证收敛的状态

```

1:  $\tilde{\mathbf{w}} \leftarrow \mathbf{0}$ 
2: for  $e = 1, \dots, E$  do
3:    $m \leftarrow 0$ 
4:   for  $i = 1, \dots, n$  do
5:      $\tilde{\mathbf{x}}_i \leftarrow (\mathbf{x}_i^\top, 1)^\top$ 
6:     if  $y_i \langle \tilde{\mathbf{w}}, \tilde{\mathbf{x}}_i \rangle \leq 0$  then
7:        $\tilde{\mathbf{w}} \leftarrow \tilde{\mathbf{w}} + \eta y_i \tilde{\mathbf{x}}_i$ 
8:        $m \leftarrow m + 1$ 
9:     end if
10:  end for
11:  if  $m = 0$  then
12:    return  $(\tilde{\mathbf{w}}, \text{已收敛})$ 
13:  end if
14: end for
15: return  $(\tilde{\mathbf{w}}, \text{达到轮数上限})$ 

```

一整轮没有更新时，所有样本都是在同一个参数下得到严格正的有符号得分，才构成收敛证据。达到轮数上限只表示预算用尽，不能据此断言数据不可分。稠密实现每轮需要 $O(nd)$ 运算，除训练集外只需 $O(d)$ 参数空间；样本访问顺序可以改变输出的分隔面。

从优化角度看，定义**感知机损失**（perceptron loss）

$$\ell_P(\tilde{\mathbf{w}}; \mathbf{x}_i, y_i) = \max\{0, -y_i \langle \tilde{\mathbf{w}}, \tilde{\mathbf{x}}_i \rangle\}. \quad (3.17)$$

负得分处的梯度为 $-y_i \tilde{\mathbf{x}}_i$ ，正得分处为 $\mathbf{0}$ ；零得分处选择次梯度 $-y_i \tilde{\mathbf{x}}_i$ ，就得到式 (3.16)。这是逐样本梯度更新；随机抽取样本时才相应成为随机次梯度下降。这里使用的是零间隔损失，不是标准的**合页损失**（hinge loss）

$\max\{0, 1 - y_i \langle \tilde{\mathbf{w}}, \tilde{\mathbf{x}}_i \rangle\}$ 。前者在零参数处就对所有样本取零，因此“感知机损失为零”本身不能证明分类正确；算法在零得分处仍更新的约定不可省略。

3.1.2.3 理论分析

收敛性分析 每次修正可能破坏已有判断，为什么这些修正不会无穷持续？关键是存在一个始终把所有样本分对的参考方向：更新朝该方向取得线性累积的进展，而参数范数的平方只能线性增长。Novikoff 在 1962 年报告的证明清楚展示了这两个增长速度之间的矛盾¹¹。

定理 3.2 感知机的错误更新界 若 D_n 满足式 (3.15)，从零参数出发，以固定 $\eta > 0$ 按式 (3.16) 更新，则对任意样本访问顺序，错误更新次数 M 满足

$$M \leq \left(\frac{R}{\gamma}\right)^2.$$

这里错误更新包括零得分时的更新。若持续完整遍历训练集，且不因预算提前退出，算法在有限轮后得到所有训练样本上有符号得分均严格为正的参数。

¹¹ A. B. J. Novikoff, *On Convergence Proofs for Perceptrons* In *Proceedings of the Symposium on the Mathematical Theory of Automata*, 1962, pp. 615–622

证明. 设第 $t+1$ 次更新使用样本 i_t 。沿单位参考方向 $\mathbf{u}^*$ 考察更新，得到

$$\begin{aligned} \langle \tilde{\mathbf{w}}^{(t+1)}, \mathbf{u}^* \rangle &= \langle \tilde{\mathbf{w}}^{(t)}, \mathbf{u}^* \rangle + \eta y_{i_t} \langle \tilde{\mathbf{x}}_{i_t}, \mathbf{u}^* \rangle \\ &\geq \langle \tilde{\mathbf{w}}^{(t)}, \mathbf{u}^* \rangle + \eta \gamma. \end{aligned}$$

从零参数累加 M 次，便有

$$\langle \tilde{\mathbf{w}}^{(M)}, \mathbf{u}^* \rangle \geq M\eta\gamma.$$

另一方面，展开更新后的平方范数：

$$\begin{aligned} \|\tilde{\mathbf{w}}^{(t+1)}\|_2^2 &= \|\tilde{\mathbf{w}}^{(t)}\|_2^2 + 2\eta y_{i_t} \langle \tilde{\mathbf{w}}^{(t)}, \tilde{\mathbf{x}}_{i_t} \rangle \\ &\quad + \eta^2 \|\tilde{\mathbf{x}}_{i_t}\|_2^2 \\ &\leq \|\tilde{\mathbf{w}}^{(t)}\|_2^2 + \eta^2 R^2. \end{aligned}$$

不等式使用了更新条件：交叉项非正；并使用同一增广空间中的长度界 R 。再次累加，得到 $\|\tilde{\mathbf{w}}^{(M)}\|_2^2 \leq M\eta^2 R^2$ 。由 Cauchy-Schwarz 不等式和 $\|\mathbf{u}^*\|_2 = 1$ ，

$$M\eta\gamma \leq \langle \tilde{\mathbf{w}}^{(M)}, \mathbf{u}^* \rangle \leq \|\tilde{\mathbf{w}}^{(M)}\|_2 \leq \eta R \sqrt{M}.$$

$M=0$ 时结论直接成立； $M>0$ 时除以 $\eta\sqrt{M}$ 再平方，得到所述界。因此更新不可能无限发生。持续完整遍历会在最后一次更新之后再检查所有

样本；若仍有非正得分就还会更新，产生矛盾，故最终必有一整轮没有更新。 ■

这个界不显式含 n ，也不依赖访问顺序，但 R 和 γ 随数据而定；增加样本可能缩小可分间隔。它只约束更新次数，不包括寻找错误时检查正确样本的开销。对于算法 3.1 的逐轮扫描，若不提前截断，至多需要 $M + 1$ 轮，包括最终的无更新确认轮。

若数据不可分，有限更新保证失效，持续遍历可能反复更新，此时可以限制训练预算并保留历史较好解，或采用允许间隔违约的在线方法。这些处理改变了停止或选解方式，仍须分别分析。

泛化分析 错误更新界不是最终分类器的测试风险界。前述证明既没有独立同分布假设，也没有说明未来数据如何产生；仅凭某个训练集上的零误差，不能控制测试误差。研究问题从“修正会不会停止”转向“怎样从训练历史中选出风险小的分类器”后，还需要抽样条件和输出规则。Cesa-Bianchi、Conconi 与 Gentile 在 2004 年系统分析了这种联系：利用独立同分布样本上的在线表现，控制历史预测规则的风险，并讨论从中选择输出的方法¹²。

下面给出一个期望风险的简单结论，说明额外条件怎样进入证明。按独立同分布的到达顺序，仅遍历 D_n 一次，从零参数出发使用固定学习率 $\eta > 0$ 和原更新规则。用 f_i 表示看到第 i 个样本之前的分类器；它只依赖 D_{i-1} ，其中 D_0 为空。这里 i 计数已访问的样本位置，与只计实际更新的 t 不同。训练后独立地从 $\{1, \dots, n\}$ 均匀抽取 I ，返回 f_I ，而不是默认返回最后一次更新后的参数。

¹² N. Cesa-Bianchi, A. Conconi, C. Gentile, *On the Generalization Ability of On-Line Learning Algorithms* In IEEE Transactions on Information Theory, 2004, vol. 50, no. 9, pp. 2050–2057

定理 3.3 随机历史分类器的期望风险 设训练样本独立同分布，测试样本独立来自同一分布。假设存在固定的单位向量 $\mathbf{u}^*$ 及常数 $R < \infty$ 、 $\gamma > 0$ ，使

$$\|\tilde{\mathbf{x}}\|_2 \leq R, \quad y(\mathbf{u}^*, \tilde{\mathbf{x}}) \geq \gamma \quad \text{几乎必然.}$$

对上述单遍历训练和随机输出规则，有

$$\mathbb{E}_{D_n, I}[R(f_I | D_n, I)] \leq \frac{R^2}{n\gamma^2}. \quad (3.18)$$

证明. 令 $e_i = \mathbb{1}\{f_i(\mathbf{x}_i) \neq y_i\}$ 。由于 f_i 尚未使用第 i 个样本，独立性给出

$$\mathbb{E}[e_i | D_{i-1}] = R(f_i | D_{i-1}).$$

对两边取期望，再对均匀的 I 平均，就有

$$\mathbb{E}_{D_n, I}[R(f_I | D_n, I)] = \frac{1}{n} \sum_{i=1}^n \mathbb{E}[e_i].$$

每次预测错误都会触发更新，零得分且预测正确时也可能更新，故 $\sum_i e_i \leq M$ 。分布层面的共同间隔和长度界使定理 3.2 几乎必然适用于每个训练序列，于是 $M \leq R^2/\gamma^2$ ，代入即得结论。 ■

这里的 R 和 γ 约束整个数据分布，而不只是碰巧可分的一份训练集。式 (3.18) 控制的是训练抽样与随机选取历史状态共同平均后的风险，不是对某次训练的高概率保证；当上界大于 1 时也没有提供非平凡信息。它不能直接套给最终参数、平均参数或反复遍历后的参数，因为这些输出与上述随机规则不同，多轮训练时当前样本也不再独立于已有参数。投票感知机等方法正是在如何利用训练历史这一环节作出不同选择，其风险需要相应的分析。

3.1.2.4 支持多分类

对 C 类问题，把标签改为 $y_i \in \{1, \dots, C\}$ ，每类维护一组增广参数 $\tilde{\mathbf{w}}_c = (\mathbf{w}_c^\top, b_c)^\top$ ，得分和预测为

$$s_c(\mathbf{x}) = \langle \tilde{\mathbf{w}}_c, \tilde{\mathbf{x}} \rangle, \quad \hat{y} = \arg \max_{c \in \{1, \dots, C\}} s_c(\mathbf{x}).$$

平局仍按最小类别索引处理。这个构造把正确类别的得分与每个竞争类别作比较，也可用 **Kesler 构造** (Kesler construction) 把这些比较写成一个扩展空间中的线性可分问题。

遇到 $\hat{y}_i \neq y_i$ 时，只提高正确类别的参数并降低错误获胜类别的参数：

$$\begin{aligned} \tilde{\mathbf{w}}_{y_i} &\leftarrow \tilde{\mathbf{w}}_{y_i} + \eta \tilde{\mathbf{x}}_i, \\ \tilde{\mathbf{w}}_{\hat{y}_i} &\leftarrow \tilde{\mathbf{w}}_{\hat{y}_i} - \eta \tilde{\mathbf{x}}_i. \end{aligned} \tag{3.19}$$

其余类别不变，两个类别的偏置也随各自最后一个分量同时更新。若平局后预测错误，同样更新；若已选择正确类别，则该规则不更新。与二分类中所有零得分均更新的约定不同，这里直接按最终预测是否正确判断。

收敛条件也必须改为多类的得分差条件。把各类参数按行堆成 $\tilde{\mathbf{W}} \in \mathbb{R}^{C \times (d+1)}$ ；假设存在 $\|\mathbf{U}^*\|_F = 1$ 和 $\gamma_{mc} > 0$ ，使对所有 i 和 $c \neq y_i$ 都有

$$\langle \mathbf{U}_{y_i, :}^* - \mathbf{U}_{c, :}^*, \tilde{\mathbf{x}}_i \rangle \geq \gamma_{mc}.$$

这里 $\|\cdot\|_F$ 是所有矩阵元素平方和的平方根，行向量的内积按对应坐标计算。一次更新的方向矩阵仅两行非零，分别为 $\tilde{\mathbf{x}}_i^\top$ 与 $-\tilde{\mathbf{x}}_i^\top$ ，其平方范数至多为

$2R^2$ 。它与 $\mathbf{U}^*$ 的内积至少为 γ_{mc} ；与当前参数的内积则为 $s_{y_i}(\mathbf{x}_i) - s_{\hat{y}_i}(\mathbf{x}_i) \leq 0$ 。因此零初始化时完全沿用二分类证明，得到

$$M\eta\gamma_{\text{mc}} \leq \|\tilde{\mathbf{W}}^{(M)}\|_F \leq \eta R\sqrt{2M}, \quad M \leq \frac{2R^2}{\gamma_{\text{mc}}^2}.$$

有限更新保证因而保留下来，但它要求所有正确类与竞争类之间都具有共同的正间隔，而不是只检查任意一对类别。

3.1.2.5 小结

感知机说明不了估计概率分布也可以学习线性边界：只要存在正间隔分隔面，误差驱动更新就能在有限次修正后找到一个可行解。但它没有规定在可行解之间怎样选择，也没有保证不可分数据上停止。围绕这些限制，形成了不同的扩展。

口袋算法 (Pocket algorithm) 处理的是“当前权重未必比过去更好”的问题。常用的带历史最优记录的版本额外保存 $\tilde{\mathbf{w}}_{\text{pocket}}$ ：每次检查候选参数时，计算全训练集零一错误数，仅在严格改进时替换记录；预算用尽后返回记录参数。它可以用于噪声或矛盾标签数据，但有限预算内只是已检查候选中的最好解，不保证全局最优，反复评估全训练集也有额外开销。Gallant 在 1990 年的论文中系统讨论了 Pocket 及相关学习方法¹³。

若问题在于原空间不能线性分开，可把输入换成特征映射 $\phi(\mathbf{x})$ 。核函数 $K(\mathbf{x}, \mathbf{z}) = \langle \phi(\mathbf{x}), \phi(\mathbf{z}) \rangle$ 直接计算映射后的内积，省去显式构造高维坐标，得到**核感知机** (kernel perceptron)。为与前文偏置一致，使用增广映射 $(\phi(\mathbf{x}), 1)$ 及其核 $\tilde{K}(\mathbf{x}, \mathbf{z}) = K(\mathbf{x}, \mathbf{z}) + 1$ 。零初始化、单位学习率下，参数在特征空间中是更新样本的线性组合，预测可写为

$$f(\mathbf{x}) = \text{sign} \left(\sum_{i=1}^n \alpha_i y_i [K(\mathbf{x}_i, \mathbf{x}) + 1] \right). \quad (3.20)$$

这里 α_i 是样本 i 的更新次数；遇到非正有符号得分时令 $\alpha_i \leftarrow \alpha_i + 1$ 。必须选用正定核，即它在任意有限输入集上生成半正定 Gram 矩阵，才能作上述内积解释；有限更新还要求增广特征空间内存在正间隔，长度界相应变为 $\sqrt{K(\mathbf{x}_i, \mathbf{x}_i) + 1}$ 的上界。预测需要访问系数非零的样本，数量可能随训练增长。将内积推广到特征空间的思路可追溯至 Aizerman、Braverman 与 Rozonoer 在 1964 年的势函数研究¹⁴。

另一类扩展保留多段训练历史。**投票感知机** (voted perceptron) 保存历次参数 $\tilde{\mathbf{w}}^{(j)}$ 及其使用时长 q_j ，以时长作为票数：

$$f_{\text{vote}}(\mathbf{x}) = \text{sign} \left(\sum_{j=1}^J q_j \text{sign}(\langle \tilde{\mathbf{w}}^{(j)}, \tilde{\mathbf{x}} \rangle) \right).$$

¹³ S. I. Gallant, *Perceptron-Based Learning Algorithms* In IEEE Transactions on Neural Networks, 1990, vol. 1, no. 2, pp. 179–191

¹⁴ M. A. Aizerman, E. M. Braverman, L. I. Rozonoer, *Theoretical Foundations of the Potential Function Method in Pattern Recognition Learning* In Automation and Remote Control, 1964, vol. 25, pp. 821–837

其中 J 为保存的参数状态数, q_j 按该参数持续使用的样本步数计数, 而不只数更新次数。**平均感知机** (averaged perceptron) 则对相同历史平均参数,

$$\tilde{\mathbf{w}} = \frac{\sum_{j=1}^J q_j \tilde{\mathbf{w}}^{(j)}}{\sum_{j=1}^J q_j}, \quad f_{\text{avg}}(\mathbf{x}) = \text{sign}(\langle \tilde{\mathbf{w}}, \tilde{\mathbf{x}} \rangle).$$

平均向量可通过累计和维护, 预测仍只需一次线性得分; 投票则需保留多个状态。先取符号再投票与先平均再取符号一般不等价。Freund 与 Schapire 在 1999 年的工作中研究了投票法, 也比较了平均法; 其大间隔泛化结论有明确的抽样和训练设置, 不能解释为二者在任意噪声数据上都优于最终参数¹⁵。

若希望每次更新不仅改正符号, 还达到指定得分间隔, **被动攻击算法** (passive-aggressive algorithm, PA) 把“尽量少改参数”和“满足当前样本的单位间隔”合成一个投影问题。用 $\mathbf{v}$ 表示待求的新增广参数,

$$\begin{aligned} \min_{\mathbf{v}} \quad & \frac{1}{2} \|\mathbf{v} - \tilde{\mathbf{w}}\|_2^2 \\ \text{满足} \quad & y_i \langle \mathbf{v}, \tilde{\mathbf{x}}_i \rangle \geq 1. \end{aligned} \quad (3.21)$$

令 $\ell_i = \max\{0, 1 - y_i \langle \tilde{\mathbf{w}}, \tilde{\mathbf{x}}_i \rangle\}$ 。约束已满足时参数不变; 否则, 拉格朗日驻点要求 $\mathbf{v} = \tilde{\mathbf{w}} + \tau_i y_i \tilde{\mathbf{x}}_i$, 将活跃约束代回即得

$$\tau_i = \frac{\ell_i}{\|\tilde{\mathbf{x}}_i\|_2^2}, \quad \tilde{\mathbf{w}} \leftarrow \tilde{\mathbf{w}} + \tau_i y_i \tilde{\mathbf{x}}_i.$$

因此 PA 在间隔足够时“被动”, 不足时按违约大小调整。增广方式也意味着这里把偏置变化纳入距离惩罚。噪声下硬性满足当前样本可能调整过大, PA-I 可用 $\tau_i = \min\{\lambda_{\text{PA}}, \ell_i / \|\tilde{\mathbf{x}}_i\|_2^2\}$ 限制步长, 其中 $\lambda_{\text{PA}} > 0$ 控制容忍程度。Crammer 等人的 2006 年论文统一分析了这些在线大间隔方法; 它们不是一次更新就求得全训练集上的最优分隔面¹⁶。

如果输出是一整条词性序列等组合对象, 可以把多分类的得分比较推广到结构之间。**结构化感知机** (structured perceptron) 用联合特征 $\phi(\mathbf{x}, y)$ 描述输入与候选结构, 预测

$$\hat{y}_i = \arg \max_{y \in Y(\mathbf{x}_i)} \langle \theta, \phi(\mathbf{x}_i, y) \rangle,$$

其中 $Y(\mathbf{x}_i)$ 是候选结构集合, θ 是与联合特征同维的参数。解码错误时进行

$$\theta \leftarrow \theta + \eta [\phi(\mathbf{x}_i, y_i) - \phi(\mathbf{x}_i, \hat{y}_i)].$$

需要的类别或结构偏置也作为联合特征中的相应指示分量处理; 对所有候选都相同的常数项会在得分差中消去。在特征差有界、正确结构与所有错误结构之间正间隔可分、且能精确解码的条件下, 可沿用多类证明。近似

¹⁵ Y. Freund, R. E. Schapire, *Large Margin Classification Using the Perceptron Algorithm In Machine Learning*, 1999, vol. 37, no. 3, pp. 277–296

¹⁶ K. Crammer, O. Dekel, J. Keshet, S. Shalev-Shwartz, Y. Singer, *Online Passive-Aggressive Algorithms In Journal of Machine Learning Research*, 2006, vol. 7, pp. 551–585

搜索则需另行分析，不能直接继承这一保证。Collins 在 2002 年将这种更新与参数平均用于序列标注，提供了词性标注和短语识别等实例，也为比较感知机与条件随机场等结构化模型提供了参照¹⁷。

这些扩展改变的是不同环节：Pocket 选择返回哪个历史解，核方法改变输入表示，投票与平均利用训练轨迹，PA 改变单步目标，结构化感知机改变输出及解码方式。它们保留了逐样本修正得分的思路，却不会自动消除各自的可分性、计算或泛化限制。理解这种区分，比把所有扩展都视为原始感知机的无条件改进更有助于选择方法。

3.1.3 支持向量机 (SVM)

感知机回答了一个基本问题：如果训练样本能够被某个超平面分开，怎样通过错误驱动的更新找到一个分离器？但分开训练样本并不意味着分界的位置已经合适。同一批可分数据往往允许许多分离超平面，即使从零参数开始，感知机的结果仍会受样本顺序和更新规则影响。一个紧贴训练样本的边界虽然没有训练错误，却可能在输入受到很小扰动时改变预测。要在这些分离器之间作出选择，还需要说明什么样的边界更值得保留。

支持向量机 (support vector machine, SVM) 用训练样本到决策边界的距离回答这一问题：在正确分离样本的前提下，尽量增大最近样本到边界的距离。这个选择准则称为最大间隔。它不是对所有噪声和所有分布都最优的保证，而是在给定特征表示与距离度量后，用一个明确的几何量约束分类器。允许部分样本违反间隔要求，可以处理不可分数据；改变计算距离所依赖的特征表示，又可以得到非线性边界。这两个扩展分别改变约束与表示，不应混为同一种改进。

最优分离超平面的早期研究可以追溯到 20 世纪 60 年代。现代支持向量分类器的一项关键进展，是 Boser、Guyon 与 Vapnik 在 1992 年把最优间隔训练和核表示结合起来¹⁸。这篇论文从分类器容量与泛化之间的关系出发，用最靠近边界的支持样本表示解，并研究了多项式和径向基等非线性分类函数。在高阶多项式情形中，显式列出全部交互特征可能难以承受，而只计算样本间的核函数可以避开这一展开。论文中的字符识别实验也让这种表示方式与具体分类任务联系起来。

1995 年 Cortes 与 Vapnik 进一步系统发展了容许训练样本违反间隔约束的支持向量网络¹⁹。这样，无法严格分开的数据也能进入带有惩罚的优化问题，间隔不再以训练样本全部正确为前提。沿着这条路线，模型表达、误差容忍与实际求解逐渐形成分工：核函数决定怎样比较输入，松弛惩罚决定怎样对待间隔违反，后面介绍的分解算法则降低每次优化所需处理的问题规模。几何建模、凸优化和统计分析因此相互联系，但仍分别回答选择什么模型、如何求解以及怎样控制新样本误差。

¹⁷ M. Collins, *Discriminative Training Methods for Hidden Markov Models: Theory and Experiments with Perceptron Algorithms* In Proceedings of the 2002 Conference on Empirical Methods in Natural Language Processing, 2002, pp. 1–8

¹⁸ B. E. Boser, I. M. Guyon, V. N. Vapnik, *A Training Algorithm for Optimal Margin Classifiers* In Proceedings of the Fifth Annual Workshop on Computational Learning Theory, 1992, pp. 144–152

¹⁹ C. Cortes, V. Vapnik, *Support-Vector Networks* In Machine Learning, 1995, vol. 20, no. 3, pp. 273–297

主线阅读只需抓住“硬间隔选择边界—软间隔容许违反—核方法改变表示—多分类组织类别竞争”这条路径，并理解训练目标与预测得分。对偶、SMO 与风险界属于进阶证明和计算细节，初读时可按需要查阅。再生核 Hilbert 空间构造和 Mercer 谱展开已放在简介的第1.2.1.2节，作为核表示的进阶背景。推导所需的凸优化背景可回顾第二卷“基础、理论和可信性”的“一般学习的可学习性”章；本节还会在首次使用处说明拉格朗日对偶、Slater 条件、KKT 条件和互补松弛，避免把这些名称当作无需解释的前提。

下面从严格线性可分的情形建立模型，推导对偶与求解过程，再分别讨论优化保证和统计保证。有了这一基础，软间隔与核方法就可以理解为对原有问题的局部修改。多分类进一步改变类别之间的比较方式，可以组合二分类器，也可以直接学习多个类别的相对得分。

3.1.3.1 模型结构

沿用二分类标签约定，设训练集为 $D_n = \{(\mathbf{x}_i, y_i)\}_{i=1}^n$ ，其中 $\mathbf{x}_i \in \mathbb{R}^d$ 、 $y_i \in \{-1, +1\}$ ，并假设两类均非空。令实值得分为 $g(\mathbf{x}) = \mathbf{w}^\top \mathbf{x} + b$ ，其中 $\mathbf{w} \in \mathbb{R}^d$ 、 $b \in \mathbb{R}$ 且 $\mathbf{w} \neq \mathbf{0}$ 。决策超平面是 $g(\mathbf{x}) = 0$ ，预测规则为 $\hat{y}(\mathbf{x}) = \text{sign}(g(\mathbf{x}))$ ；若得分恰为零，约定预测为 $+1$ 。后文会将零得分保守地计入间隔错误，因此这个平局约定不影响风险上界。

仅比较 $y_i g(\mathbf{x}_i)$ 还不能比较不同超平面。把 $(\mathbf{w}, b)$ 同时乘以任意正数，分类结果不变，这个数值却会随之放大。为区分参数尺度与真实距离，定义样本的**函数间隔**（functional margin）为 $m_i = y_i g(\mathbf{x}_i)$ ，定义其**几何间隔**（geometric margin）为

$$\gamma_i = \frac{y_i(\mathbf{w}^\top \mathbf{x}_i + b)}{\|\mathbf{w}\|_2}, \quad \gamma = \min_{1 \leq i \leq n} \gamma_i. \quad (3.22)$$

函数间隔保留了得分的尺度；几何间隔除以法向量长度，得到沿法向方向测量的有符号距离。样本分类正确时，这个距离为正。若输入改变为 $\mathbf{x}_i + \Delta$ ，由 Cauchy-Schwarz 不等式可得

$$y_i g(\mathbf{x}_i + \Delta) \geq y_i g(\mathbf{x}_i) - \|\mathbf{w}\|_2 \|\Delta\|_2.$$

因此， $\|\Delta\|_2 < \gamma_i$ 时预测不会翻转。这说明间隔刻画的是当前特征空间中对输入扰动的容忍程度，而不是对任意分布变化的鲁棒性。

严格线性可分意味着存在 $(\mathbf{w}, b)$ 使所有 $m_i > 0$ 。由于样本数有限，可将这组参数除以 $\min_i m_i$ ，得到 $\min_i m_i = 1$ 的规范化表示。在该表示下，最近样本到决策超平面的单侧距离为 $1/\|\mathbf{w}\|_2$ ；两个平行超平面 $g(\mathbf{x}) = +1$ 与 $g(\mathbf{x}) = -1$ 之间的总宽度则是 $2/\|\mathbf{w}\|_2$ 。本节将前者记为 γ ，不把单侧间隔与两侧带宽混用。

最大化 γ 于是等价于最小化 $\|\mathbf{w}\|_2$ 。平方与正比例因子不改变最优解, 却使求导更方便, 得到**硬间隔** (hard margin) SVM 的原始问题:

$$\begin{aligned} \min_{\mathbf{w}, b} \quad & \frac{1}{2} \|\mathbf{w}\|_2^2 \\ \text{s.t.} \quad & y_i(\mathbf{w}^\top \mathbf{x}_i + b) \geq 1, \quad i = 1, \dots, n. \end{aligned} \quad (3.23)$$

这里的“硬”表示每个样本都必须满足间隔约束, 不能用其他样本的改善来补偿某个样本的违反。约束写为大于等于 1 并没有放弃规范化: 若一个可行解的最小函数间隔严格大于 1, 将参数一起缩小就能降低目标, 所以最优解必有紧约束。

定理 3.4 硬间隔解的存在性与唯一性 若有限训练集严格线性可分且两类均非空, 则问题(3.23)存在唯一的规范化最优参数 $(\mathbf{w}^*, b^*)$ 。目标函数只对 $\mathbf{w}$ 严格凸, 偏置的唯一性还需要两类约束共同确定。

证明. 取一个可行解, 并把目标限制在不超过该解目标值的水平集上, 则 $\mathbf{w}$ 有界。固定一个正类样本与一个负类样本, 它们的约束分别给出 b 的下界与上界; 因为 $\mathbf{w}$ 有界, b 也有界。该水平集闭且非空, 因此连续目标能在其中取得最小值。

若两个最优解的权重不同, 其平均仍可行, 但平方范数的严格凸性会使平均解的目标更小, 产生矛盾。因此所有最优解共享同一个 $\mathbf{w}^*$ 。为研究 b , 对给定 $\mathbf{w}$ 定义两类样本的投影端点

$$a_+(\mathbf{w}) = \min_{i: y_i=+1} \mathbf{w}^\top \mathbf{x}_i, \quad a_-(\mathbf{w}) = \max_{i: y_i=-1} \mathbf{w}^\top \mathbf{x}_i.$$

可行偏置恰好满足

$$1 - a_+(\mathbf{w}) \leq b \leq -1 - a_-(\mathbf{w}),$$

所以投影间距 $a_+(\mathbf{w}) - a_-(\mathbf{w})$ 至少为 2。若在最优 $\mathbf{w}^*$ 处它严格大于 2, 令 $\theta = 2/(a_+ - a_-) < 1$, 取新权重 $\theta \mathbf{w}^*$ 和新偏置 $-\theta(a_+ + a_-)/2$, 则两类最近样本的函数间隔都为 1, 其余样本仍满足约束, 而非零权重的范数严格减小。这与最优性矛盾。故最优投影间距只能等于 2, 可行偏置区间收缩为单点, b^* 也唯一。 ■

这个证明还表明, 最优解的两个支持超平面都至少接触一个训练样本。唯一性属于固定数据与固定特征表示下的规范化硬间隔问题, 不意味着更换特征、加入噪声或放松约束以后仍有同样的结论。

示例 3.5 单侧间隔与带宽 考虑一维教学数据 $(x_1, y_1) = (-1, -1)$ 、 $(x_2, y_2) = (1, +1)$ 、 $(x_3, y_3) = (-2, -1)$ 和 $(x_4, y_4) = (2, +1)$ 。任意落在 -1 与 1 之间的阈值都能正确分类，但只有阈值 0 使两侧最近距离的较小者达到最大。规范化最优解为 $w^* = 1$ 、 $b^* = 0$ ；最近样本的单侧距离为 1 ，两条支持超平面在此退化为两个点 -1 与 1 ，其间距离为 2 。更远的两个样本不限制这一最优间隔。

3.1.3.2 参数学习

原始问题可以交给凸二次规划求解器，但直接优化 $\mathbf{w}$ 不是唯一途径。每个约束究竟在多大程度上限制了最优边界，可以通过与它对应的拉格朗日乘子表示。转到**对偶问题** (dual problem)，就是改为优化这些约束权重；它既能揭示哪些样本真正参与决策，也能把训练样本的使用方式压缩为样本内积。这是后面引入核方法的关键，而不是说对偶在所有 n 、 d 组合下都比原始问题便宜。

将约束写为 $1 - y_i(\mathbf{w}^\top \mathbf{x}_i + b) \leq 0$ ，引入 $\alpha_i \geq 0$ ，记 $\boldsymbol{\alpha} = (\alpha_1, \dots, \alpha_n)^\top$ 。拉格朗日函数为

$$L(\mathbf{w}, b, \boldsymbol{\alpha}) = \frac{1}{2} \|\mathbf{w}\|_2^2 + \sum_{i=1}^n \alpha_i [1 - y_i(\mathbf{w}^\top \mathbf{x}_i + b)]. \quad (3.24)$$

对一个可行 $(\mathbf{w}, b)$ ， $\sup_{\boldsymbol{\alpha} \geq 0} L$ 等于原始目标；若有约束违反，对应乘子趋于无穷会使上确界为正无穷。因此原始最优值可写为 $\inf_{\mathbf{w}, b} \sup_{\boldsymbol{\alpha} \geq 0} L$ 。反过来，先对 $(\mathbf{w}, b)$ 取下确界再最大化，得到原始最优值的下界。两种次序能否给出相同的值，需要强对偶条件，不能只根据形式交换极值。

这里可以直接核验**Slater 条件** (Slater's condition)：它要求存在严格满足不等式约束的点。取一个严格分离器，并把参数放大到所有函数间隔都严格大于 1 ，就得到所需点。结合目标凸、约束仿射以及上一小节的最优值可达性，可得强对偶与最优乘子的存在性。

现在计算 $q(\boldsymbol{\alpha}) = \inf_{\mathbf{w}, b} L(\mathbf{w}, b, \boldsymbol{\alpha})$ 。由于 b 没有二次项，若 $\sum_i \alpha_i y_i \neq 0$ ，沿 b 的某个方向就有 $L \rightarrow -\infty$ 。要使 q 有限，必须满足等式约束；关于 $\mathbf{w}$ 的极小值则由驻点给出：

$$\mathbf{w} = \sum_{i=1}^n \alpha_i y_i \mathbf{x}_i, \quad \sum_{i=1}^n \alpha_i y_i = 0. \quad (3.25)$$

令 $\mathbf{v} = \sum_i \alpha_i y_i \mathbf{x}_i$ ，代入后涉及权重的两项变为 $\frac{1}{2} \|\mathbf{v}\|_2^2 - \|\mathbf{v}\|_2^2$ ，而 b 项为零。

展开 $\|\mathbf{v}\|_2^2$, 便得到

$$\begin{aligned} \max_{\alpha} \quad & q(\alpha) = \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i,j=1}^n \alpha_i \alpha_j y_i y_j \mathbf{x}_i^\top \mathbf{x}_j \\ \text{s.t.} \quad & \sum_{i=1}^n \alpha_i y_i = 0, \quad \alpha_i \geq 0, \quad i = 1, \dots, n. \end{aligned} \quad (3.26)$$

二次项矩阵的元素为 $\mathbf{Q}_{i,j} = y_i y_j \mathbf{x}_i^\top \mathbf{x}_j$ 。对任意 $\mathbf{a} \in \mathbb{R}^n$, 有 $\mathbf{a}^\top \mathbf{Q} \mathbf{a} = \|\sum_i a_i y_i \mathbf{x}_i\|_2^2 \geq 0$, 所以 q 是凹函数; 它未必严格凹, 因而对偶乘子未必唯一。

原始解与对偶解的联系可以用 **Karush-Kuhn-Tucker 条件** (Karush-Kuhn-Tucker conditions, KKT 条件) 完整表达。它们同时检查解是否满足约束、是否达到驻点, 以及一个约束是否真的限制了目标的继续改善。在当前凸问题与 Slater 条件下, 这组条件对最优性既必要又充分:

$$\begin{aligned} m_i^* &= y_i g^*(\mathbf{x}_i) \geq 1, \quad \alpha_i^* \geq 0, \\ \alpha_i^* (m_i^* - 1) &= 0, \quad i = 1, \dots, n, \\ \mathbf{w}^* &= \sum_{i=1}^n \alpha_i^* y_i \mathbf{x}_i, \quad \sum_{i=1}^n \alpha_i^* y_i = 0. \end{aligned} \quad (3.27)$$

其中第三个关系是**互补松弛** (complementary slackness): 乘子与约束的剩余量不能同时为正。最后一行是关于权重与偏置的驻点条件。

把 $\alpha_i^* > 0$ 的样本称为**支持向量** (support vector), 并记其索引集为 $S = \{i : \alpha_i^* > 0\}$ 。互补松弛说明, 支持向量一定满足 $m_i^* = 1$, 而 $m_i^* > 1$ 必有 $\alpha_i^* = 0$ 。反向推断却不成立: 落在边界上的样本也可能具有零乘子。例如把示例3.5中的 $x_2 = 1$ 重复一次, 正类边界点的乘子总和仍可为 $1/2$, 但这个总量可以全部分配给其中一个副本。超平面没有改变, 对偶表示与支持向量索引集却可能改变。

求得 α^* 后, 恢复模型只需

$$\begin{aligned} \mathbf{w}^* &= \sum_{i \in S} \alpha_i^* y_i \mathbf{x}_i, \\ b^* &= y_k - (\mathbf{w}^*)^\top \mathbf{x}_k, \quad k \in S. \end{aligned} \quad (3.28)$$

精确最优解下, 任意支持向量都会给出同一偏置; 数值计算中可以平均多个合适样本给出的估计。只有非零乘子进入预测, 这就是 SVM 的稀疏表示。但稀疏不等于支持向量一定很少, 某些数据集可以让大部分甚至全部训练点成为支持向量。

SMO 算法 对偶把未知量换成了 n 个乘子, 也带来了新的计算负担。若存储完整内积矩阵, 需要 $O(n^2)$ 空间; 通用稠密求解中的一次矩阵分解就可

能需要 $O(n^3)$ 运算，具体总成本还取决于求解器与迭代次数。为了避开每轮求解大规模二次规划，Platt 提出了**序列最小优化** (sequential minimal optimization, SMO)：每次只优化一个最小的可动变量组，把整个问题分解为可解析处理的二维子问题²⁰。

为什么不能每次只动一个乘子？因为 $\sum_i \alpha_i y_i = 0$ 且 $y_i \neq 0$ ，单独改变一个 α_i 会破坏等式约束。选择两个不同索引 i, j ，固定其余乘子，记更新前数值为 $\alpha_i^{(t)}, \alpha_j^{(t)}$ ，并令 $s = y_i y_j \in \{-1, +1\}$ 。如果把新的 α_j 写为 u ，等式约束要求

$$\alpha_i(u) = \alpha_i^{(t)} + s(\alpha_j^{(t)} - u). \quad (3.29)$$

这样二维问题实际上只剩一个自由变量。对硬间隔，要求 $u \geq 0$ 且 $\alpha_i(u) \geq 0$ ，可行区间 $[L, H]$ 为

$$\begin{aligned} s = +1 : \quad L &= 0, \quad H = \alpha_i^{(t)} + \alpha_j^{(t)}, \\ s = -1 : \quad L &= \max\{0, \alpha_j^{(t)} - \alpha_i^{(t)}\}, \quad H = +\infty. \end{aligned} \quad (3.30)$$

同号时两乘子之和固定，因而有有限上界；异号时差固定，二者可以同时增大。这两种区间的差别来自标签符号对等式约束的影响。

为求沿这个区间的最优点，定义 $\mathbf{K}_{i,j} = \mathbf{x}_i^\top \mathbf{x}_j$ ，并使用当前实值得分计算误差缓存

$$E_k = g^{(t)}(\mathbf{x}_k) - y_k, \quad g^{(t)}(\mathbf{x}) = \sum_{\ell=1}^n \alpha_\ell^{(t)} y_\ell \mathbf{x}_\ell^\top \mathbf{x} + b^{(t)}.$$

E_k 保留实值得分相对于标签的偏差，因而包含更新所需的距离信息；经过 sign 得到的离散预测标签不再包含这部分信息。令 $\Delta = u - \alpha_j^{(t)}$ 。由于 $\Delta \alpha_i = -s\Delta$ ，权重变化为 $y_j \Delta (\mathbf{x}_j - \mathbf{x}_i)$ ，代入 q 可以逐项得到

$$\begin{aligned} q(u) - q(\alpha_j^{(t)}) &= y_j(E_i - E_j)\Delta - \frac{1}{2}\eta\Delta^2, \\ \eta &= \mathbf{K}_{i,i} + \mathbf{K}_{j,j} - 2\mathbf{K}_{i,j} \\ &= \|\mathbf{x}_i - \mathbf{x}_j\|_2^2 \geq 0. \end{aligned} \quad (3.31)$$

这里 $q(u)$ 表示其余乘子固定、 α_i 按式(3.29)联动后的目标。偏置不出现在对偶目标中；误差差 $E_i - E_j$ 中的 $b^{(t)}$ 也恰好相消。

当 $\eta > 0$ 时，一元凹二次函数的无约束最优点与区间最优点分别为

$$\begin{aligned} u_{\text{unc}} &= \alpha_j^{(t)} + \frac{y_j(E_i - E_j)}{\eta}, \\ \alpha_j^{(t+1)} &= \min\{H, \max\{L, u_{\text{unc}}\}\}, \\ \alpha_i^{(t+1)} &= \alpha_i^{(t)} + s(\alpha_j^{(t)} - \alpha_j^{(t+1)}). \end{aligned} \quad (3.32)$$

²⁰ J. C. Platt, *Sequential Minimal Optimization: A Fast Algorithm for Training Support Vector Machines*, Technical Report MSR-TR-98-14, Microsoft Research, 1998

剪裁只对一个自由变量进行，再由等式回代另一个；独立剪裁两个乘子会破坏耦合约束。若 $L = H$ ，该变量对没有可行移动，应另选工作集。

$\eta = 0$ 时，式(3.31)变为线性函数，在有限区间上比较两个端点的目标即可；若目标恒定，保留旧值避免无效移动。严格可分的线性硬间隔问题中， $\eta = 0$ 意味着两输入重合，它们不可能异号；同号重复点的目标沿可行线恒定。若出现零曲率、无穷上界且目标沿该方向无限增加，则应检查可分性假设、核矩阵与数值误差，并停止该次更新。

乘子更新以后还要调整偏置。记 $\Delta\alpha_i = \alpha_i^{(t+1)} - \alpha_i^{(t)}$ ， $\Delta\alpha_j$ 同理。分别要求更新后的第 i 或第 j 个样本具有函数间隔 1，解得

$$\begin{aligned} b_i &= b^{(t)} - E_i - y_i\Delta\alpha_i\mathbf{K}_{i,i} - y_j\Delta\alpha_j\mathbf{K}_{i,j}, \\ b_j &= b^{(t)} - E_j - y_i\Delta\alpha_i\mathbf{K}_{i,j} - y_j\Delta\alpha_j\mathbf{K}_{j,j}. \end{aligned} \quad (3.33)$$

硬间隔中，若更新后的 $\alpha_i > 0$ ，使用 b_i ；否则若 $\alpha_j > 0$ ，使用 b_j 。二者都为正且子问题精确求解时，这两个值一致；若都不能用于确定偏置，可暂取 $(b_i + b_j)/2$ 。这一步利用当前工作集的条件更新偏置，其他样本是否满足 KKT 仍由后续全局扫描检查。

令 $\Delta b = b^{(t+1)} - b^{(t)}$ ，其他样本的缓存可由

$$E_k^{(t+1)} = E_k^{(t)} + y_i\Delta\alpha_i\mathbf{K}_{i,k} + y_j\Delta\alpha_j\mathbf{K}_{j,k} + \Delta b$$

更新，不必重新计算整个预测和。在示例3.5中，从 $\alpha^{(0)} = \mathbf{0}$ 、 $b^{(0)} = 0$ 开始，选择 $x_1 = -1$ 与 $x_2 = 1$ ，有 $E_1 = 1$ 、 $E_2 = -1$ 、 $\eta = 4$ ，于是得到 $\alpha_1 = \alpha_2 = 1/2$ 和 $b = 0$ 。此时 $w = 1$ ，其余两个样本已经在间隔外；这一例子恰好一步达到最优，不能据此推断一般数据的迭代次数。

算法 3.2 硬间隔 SMO 的训练框架

输入： 两类非空且严格可分的 D_n ，容差 $\varepsilon_{\text{opt}} > 0$ ，迭代上限 t_{max}

输出： 可行乘子、偏置及停止状态

- 1: 初始化 $\alpha^{(0)} = \mathbf{0}$ 、 $b^{(0)} = 0$ 、 $E_k = -y_k$
- 2: **for** $t = 0, \dots, t_{\text{max}} - 1$ **do**
- 3: 扫描 KKT 残差；若全部低于容差，返回“容差满足”
- 4: 选取违反 KKT 的索引 i ，再选有可行改进的 j
- 5: 按式(3.30)计算 L, H
- 6: 求解一元子问题；退化时比较端点或更换变量对
- 7: 联动更新两个乘子，更新 b 与误差缓存
- 8: **end for**
- 9: 返回当前参数及“达到迭代上限，尚未认证收敛”

对于硬间隔， $\alpha_i = 0$ 时应检查 $m_i \geq 1$ ， $\alpha_i > 0$ 时应检查 $m_i = 1$ ，实际实现还要给“零乘子”设置数值容差。第二个变量可以优先选择误差差较大或预测目标增益较大的样本，但必须有回退扫描，不能永远忽略某些违反

条件的变量。算法3.2给出的是共同框架，具体选点规则的收敛条件留在下一小节讨论。

SMO 及其变种无需存放并分解整个稠密二次规划矩阵，不过核缓存仍可能占用可观空间。LIBSVM 采用的是带工作集选择策略的 SMO 类分解方法，而非原始 Platt 算法的逐行实现；scikit-learn 的 SVC 使用 LIBSVM 作为后端²¹。

在线性问题中，也可以直接维护 w ，采用原始问题的次梯度方法或合适的坐标下降算法。LIBLINEAR 面向大规模稀疏线性分类提供了专门求解路线，避免把所有训练问题都转成稠密核矩阵运算²²。

3.1.3.3 理论分析

一个训练程序给出低目标值，并不能直接说明它找到了最优解；即便已经找到最优解，也不能据此断言测试误差很低。这两个缺口分别需要优化分析与统计分析来弥补。硬间隔的几何结构让两种分析可以共享范数与间隔，但它们的量词、假设和结论仍须分开。

收敛性分析 凸性消除了非全局的局部极小值：一个满足全部 KKT 条件的可行解就是全局最优解。这是对解的判别，不是对任意迭代过程的保证。算法仍可能反复选择没有有效移动的变量对，或者一直忽略另一组违反 KKT 的变量；只知道目标不下降，也无法排除它收敛到一个非最优值。

对 SMO 而言，式(3.31)说明，精确最大化当前子问题不会降低对偶目标。如果 $\eta > 0$ 、无约束最优点可行且更新非零，那么增益为 $\eta\Delta^2/2 > 0$ 。但这些正增益可以越来越小，单调且有上界只足以推出目标值序列有极限，不能推出有限次更新恰好命中最优解。乘子本身不唯一时，目标值收敛与参数序列收敛还可能是不同问题。

Osuna 等对 SVM 分解求解提出了早期训练方法与分析，关键是怎样通过较小的工作集持续修复违反最优性条件的变量，而不是对任意坐标选择作出无条件保证²³。

广义 SMO 的收敛研究进一步明确了算法规则与收敛结论之间的关系；工作集选择、退化情形处理和子问题求解方式都属于定理的条件²⁴。

实际求解器通常报告“在指定容差内满足 KKT”，而不是“有限步得到精确实数最优解”。例如 Fan 等利用二阶信息选择工作集，并对所给算法建立收敛性质，这类结果应与对应选点规则一起使用²⁵。若迭代上限先于容差条件触发，则只能报告当前近似解。对于硬间隔，还必须先有可分性使原始问题可行；软间隔通过松弛变量消除这一可行性障碍，但不会自动替任意求解器建立收敛证明。

²¹ C.-C. Chang, C.-J. Lin, *LIBSVM: A Library for Support Vector Machines* In ACM Transactions on Intelligent Systems and Technology, 2011, vol. 2, no. 3, pp. 27:1–27:27

²² R.-E. Fan, K.-W. Chang, C.-J. Hsieh, X.-R. Wang, C.-J. Lin, *LIBLINEAR: A Library for Large Linear Classification* In Journal of Machine Learning Research, 2008, vol. 9, pp. 1871–1874

²³ E. Osuna, R. Freund, F. Girosi, *An Improved Training Algorithm for Support Vector Machines* In Neural Networks for Signal Processing VII: Proceedings of the 1997 IEEE Signal Processing Society Workshop, 1997, pp. 276–285

²⁴ S. S. Keerthi, E. G. Gilbert, *Convergence of a Generalized SMO Algorithm for SVM Classifier Design* In Machine Learning, 2002, vol. 46, no. 1–3, pp. 351–360

²⁵ R.-E. Fan, P.-H. Chen, C.-J. Lin, *Working Set Selection Using Second Order Information for Training Support Vector Machines* In Journal of Machine Learning Research, 2005, vol. 6, pp. 1889–1918

泛化分析 统计分析需要把训练中获得的间隔与独立测试样本的风险联系起来。以下分别从函数类的复杂度和删除训练样本后的解变化入手，再与感知机的错误更新界比较。

基于间隔的泛化界。最大间隔为什么可能有利于新样本？可以预先限制得分函数的范数，再研究其中具有较大训练间隔的函数。线性分类器的几何边界由符号决定；若不固定得分尺度，单靠 $\|\mathbf{w}\|_2$ 小还不足以限制分类能力，因为任意非零参数都可以同比缩小而保持分类不变。范数与函数间隔必须共同出现。

第二卷“基础、理论和可信性”的“二分类学习的可学习性”章“估计期望风险”节已经介绍用 Rademacher 复杂度控制这类得分函数，第二卷“基础、理论和可信性”的“二分类学习的可学习性”章中的间隔风险界给出了无偏置线性模型的间隔风险界。这里补入 SVM 常用的偏置项，并明确所有上界都在抽样前固定。设独立同分布样本满足 $\|\mathbf{x}\|_2 \leq R$ 几乎处处，给定 $B > 0$ 与 $B_b \geq 0$ ，考虑

$$\mathcal{F}_{B,B_b} = \{\mathbf{x} \mapsto \mathbf{w}^\top \mathbf{x} + b : \|\mathbf{w}\|_2 \leq B, |b| \leq B_b\}.$$

这里的输入界约束整个数据分布，而不只是已经看到的训练点。偏置也必须得到处理：若直接让 b 任意大，下面对实值得分函数的复杂度估计便不成立。

为了把得分转换成误差，固定 $\rho > 0$ 并使用**截断间隔损失** (ramp loss)

$$\ell_\rho(z) = \begin{cases} 1, & z \leq 0, \\ 1 - z/\rho, & 0 < z < \rho, \\ 0, & z \geq \rho. \end{cases} \quad (3.34)$$

它把错误分类和零得分记为 1，把达到函数间隔 ρ 的样本记为 0，中间线性过渡；其 Lipschitz 常数是 $1/\rho$ 。它用于风险分析，不是把硬间隔训练目标改成这个非凸损失。

定理 3.6 含偏置的间隔风险界 在上述输入有界假设下，固定 B, B_b, ρ 与 $\delta \in (0, 1)$ 。以至少 $1 - \delta$ 的概率，对所有 $g \in \mathcal{F}_{B,B_b}$ 同时有

$$\begin{aligned} R_{01}(g) &\leq \hat{R}_\rho(g) + \frac{2(BR + B_b)}{\rho\sqrt{n}} + \sqrt{\frac{\log(1/\delta)}{2n}}, \\ \hat{R}_\rho(g) &= \frac{1}{n} \sum_{i=1}^n \ell_\rho(y_i g(\mathbf{x}_i)), \end{aligned} \quad (3.35)$$

其中 $R_{01}(g) = \mathbb{P}(\hat{y}(\mathbf{x}) \neq y)$ 是零一风险。

证明. 因为 $1\{\hat{y}(\mathbf{x}) \neq y\} \leq \ell_\rho(yg(\mathbf{x}))$, 只需控制右侧损失的期望。令 $\sigma_1, \dots, \sigma_n$ 为独立等概率取 ± 1 的 Rademacher 变量。固定样本后, 有符号得分分类的经验复杂度满足

$$\begin{aligned} & \frac{1}{n} \mathbb{E}_\sigma \sup_{\|\mathbf{w}\|_2 \leq B, |b| \leq B_b} \sum_{i=1}^n \sigma_i y_i (\mathbf{w}^\top \mathbf{x}_i + b) \\ & \leq \frac{B}{n} \mathbb{E}_\sigma \left\| \sum_i \sigma_i y_i \mathbf{x}_i \right\|_2 + \frac{B_b}{n} \mathbb{E}_\sigma \left| \sum_i \sigma_i y_i \right| \\ & \leq \frac{B}{n} \sqrt{\sum_i \|\mathbf{x}_i\|_2^2} + \frac{B_b}{\sqrt{n}} \leq \frac{BR + B_b}{\sqrt{n}}. \end{aligned}$$

第二步先用 Jensen 不等式, 再展开平方; 独立随机符号使交叉项的期望为零。这个上界对所有样本成立, 取样本期望后也约束期望 Rademacher 复杂度。由收缩引理, 复合损失类的复杂度至多为该值的 $1/\rho$ 倍; 需要零点条件时, 可以先减去常数 $\ell_\rho(0)$, 不改变复杂度。对取值在 $[0, 1]$ 内的固定损失类, 期望 Rademacher 风险界给出两倍复杂度项与 $\sqrt{\log(1/\delta)/(2n)}$ 的置信项, 即得结论。■

这一推导沿用基于 Rademacher 复杂度的一致风险分析, 关键在于它同时覆盖一个预先给定函数类中的所有候选者, 因而也覆盖训练后从中选出的模型²⁶。

硬间隔规范化解的训练函数间隔至少为 1, 取 $\rho = 1$ 时经验间隔损失为零; 在该解属于预设函数类的前提下, 较小的范数会带来较小的复杂度上界。无偏置时, $\rho/\|\mathbf{w}\|_2$ 正是对应的几何间隔, 主要复杂度因子可以理解“输入半径除以间隔”, 而不必直接依赖 d 。

SVM 通常不正则化 b , 因此式(3.35)需要单独控制偏置。在两类非空的可分数据上, 若已有 $\|\mathbf{w}^*\|_2 \leq B$ 和输入界 R , 前面的偏置区间证明可给出一个确定的有限偏置界, 例如 $|b^*| \leq BR + 1$ 。另一种处理是把常数特征增广进输入并同时约束其系数, 得到一个不同的范数约束模型。

增广表示也便于说明半径与间隔怎样限制容量。令 $\tilde{\mathbf{x}} = (\mathbf{x}^\top, 1)^\top \in \mathbb{R}^{d+1}$, 在所考察输入域上有 $\|\tilde{\mathbf{x}}\|_2 \leq \tilde{R}$, 并预先固定 $\tilde{\gamma} > 0$ 。如果 m 个点的每一种 ± 1 标记都能由某个单位增广参数 $\mathbf{u} \in \mathbb{R}^{d+1}$ 实现, 且每个点均满足 $y_i \mathbf{u}^\top \tilde{\mathbf{x}}_i \geq \tilde{\gamma}$, 就称这些点能被以 $\tilde{\gamma}$ 的间隔打散 (margin shattering)。记这种可打散点数的最大值为 $h_{\tilde{\gamma}}$, 则

$$h_{\tilde{\gamma}} \leq \min \left\{ d + 1, \left\lceil \frac{\tilde{R}^2}{\tilde{\gamma}^2} \right\rceil \right\}. \quad (3.36)$$

半径项可以用随机符号证明。对每一组独立随机符号 $\sigma_1, \dots, \sigma_m$, 按间隔打

²⁶ P. L. Bartlett, S. Mendelson, *Rademacher and Gaussian Complexities: Risk Bounds and Structural Results* In Journal of Machine Learning Research, 2002, vol. 3, pp. 463–482

散的定義選擇對應的單位參數 $\mathbf{u}_\sigma$, 則

$$m\tilde{\gamma} \leq \mathbf{u}_\sigma^\top \sum_{i=1}^m \sigma_i \tilde{\mathbf{x}}_i \leq \left\| \sum_{i=1}^m \sigma_i \tilde{\mathbf{x}}_i \right\|_2.$$

兩邊平方並對隨機符號取期望, 交叉項消失, 得到 $m^2\tilde{\gamma}^2 \leq \sum_i \|\tilde{\mathbf{x}}_i\|_2^2 \leq m\tilde{R}^2$, 所以 $m \leq \lceil \tilde{R}^2/\tilde{\gamma}^2 \rceil$ 。維數項來自線性相關性: 若 $m > d+1$, 存在非零係數滿足 $\sum_i a_i \tilde{\mathbf{x}}_i = \mathbf{0}$; 按非零 a_i 的符號指定標籤, 間隔條件卻會推出 $\mathbf{u}^\top \sum_i a_i \tilde{\mathbf{x}}_i \geq \tilde{\gamma} \sum_i |a_i| > 0$, 矛盾。

這裡控制的是每一種標籤都要保留規定距離的打散能力; 普通 VC 維只要求標籤可實現, 不要求固定的正間隔。因此, 觀察到某一份已標記數據具有大間隔, 並不會改變整個半空間族的 VC 維。增廣表示中的歸一化間隔為 $y_i(\mathbf{w}^\top \mathbf{x}_i + b)/\sqrt{\|\mathbf{w}\|_2^2 + b^2}$, 也不同于標準 SVM 只用 $\|\mathbf{w}\|_2$ 歸一化的間隔。式(3.36)揭示了半徑與間隔共同限制容量的原因, 具體風險保證仍可使用前面的 Rademacher 界並明確偏置約定。

如果看過數據後才把 B 設為擬合范數、把 ρ 設為觀察到的最小間隔, 再直接套用固定參數的概率結論, 就遺漏了選擇這些量的代價。可以預設一系列嵌套范數類並分配失敗概率, 通過并集界實施**結構風險最小化**(structural risk minimization, SRM), 也可以用獨立驗證選擇超參數。大間隔理論支持的是這樣帶有容量約束與選擇控制的結論, 不是單個訓練集上的間隔數值本身就構成泛化保證。

基於支持向量數的留一法界。間隔界從函數類出發; 另一種分析直接考察刪除一個樣本會不會改變最優解。記 A 為精確求解硬間隔問題的学习器: 兩類非空且可分時返回唯一超平面, 訓練集只含一類時返回該類的常值分類器。對 $n \geq 2$, 定義**留一法**(leave-one-out, LOO) 誤差為

$$\hat{R}_{\text{LOO}}(D_n) = \frac{1}{n} \sum_{i=1}^n \mathbf{1}\{A(D_n \setminus \{(\mathbf{x}_i, y_i)\})(\mathbf{x}_i) \neq y_i\}. \quad (3.37)$$

這裡刪除的是第 i 個觀測, 即使兩個輸入相同, 也把它們視為不同訓練觀測。對固定訓練集, 選定一組最優乘子, 仍記 $S = \{i : \alpha_i^* > 0\}$ 。

定理 3.7 硬間隔的支持向量計數界 若 D_n 嚴格線性可分且兩類均非空, 則上述學習器滿足

$$\hat{R}_{\text{LOO}}(D_n) \leq \frac{|S|}{n}.$$

證明. 考慮一個 $\alpha_i^* = 0$ 的觀測。刪除它後, 原始解仍滿足剩餘約束; 同時刪除零乘子, 不改變 $\mathbf{w}^*$ 的表示和 $\sum_j \alpha_j^* y_j = 0$, 剩餘的互補松弛條件也全部保留。所以原始解與剩餘乘子仍滿足縮小問題的 KKT 條件, 仍然最優。

删除零乘子观测不会恰好删去某一类的唯一成员：若一类仅有一个观测且其乘子为零，等式约束将迫使另一类的所有非负乘子也为零，从而 $\mathbf{w}^* = \mathbf{0}$ ，与两类硬间隔可行性矛盾。因此缩小后的数据仍有两类，由定理3.4，其最优超平面与原来完全一致，被删观测仍被正确预测。

留一错误于是只能发生在 S 内，每个这样的观测至多贡献一次错误，求和并除以 n 即得结论。支持向量被删除也未必引起错误，因此这里是上界而非等式。 ■

这个证明使用了精确最优解与删除零乘子观测后的解不变性，不能原样推广到任意近似求解器、任意软间隔偏置选择或其他不稳定的解选择规则。对偶表示不唯一并不破坏上述论证：固定任意一组最优乘子，删除其中的零系数后，KKT 证明仍成立。

若数据独立同分布，且含两类的相关有限样本几乎必然严格线性可分，则每一个被留出的观测都独立于其余 $n-1$ 个观测。再由交换性，留一误差中的各项具有相同期望，得到

$$\begin{aligned} \mathbb{E}_{D_{n-1}} R_{01}(A(D_{n-1})) &= \mathbb{E}_{D_n} \hat{R}_{\text{LOO}}(D_n) \\ &\leq \frac{\mathbb{E}_{D_n} |S(D_n)|}{n}. \end{aligned} \quad (3.38)$$

只含一类的样本采用前述常值规则，并把其 S 记为空集，相同关系仍适用。左侧是用 $n-1$ 个观测训练的学习器的期望风险，不是当前 n 样本模型的条件风险。当前训练集的 $|S|/n$ 可以作为留一误差的可计算上界，但没有额外概率分析时，不能把它宣称为当前模型真实风险的无条件上界。

与感知机 Novikoff 定理的对比。感知机的 Novikoff 错误次数界也包含 $(R/\gamma)^2$ 。在相同输入范数、偏置处理和间隔约定下，这种形式相近来自同一几何事实：较小的输入半径与较大的分离间隔，限制了错误驱动更新能够持续发生的程度。但 Novikoff 定理计数的是感知机沿训练序列犯错并更新的次数，不是对任意测试分布的风险界。

SVM 的间隔风险界则需要独立同分布抽样，并将训练间隔、候选函数类的范数与样本量共同联系起来。感知机不保证找到最小范数解或最大间隔解，SVM 也不因为优化了最大间隔就对所有问题取得更低测试误差。两种结果提供了不同层面的信息：前者解释一个在线更新过程何时停止犯训练错误，后者解释在额外统计条件下，什么样的间隔结构有助于控制新样本错误。

3.1.3.4 支持几乎线性分类（软间隔）

硬间隔要求每个观测都能被严格分开。只要两个相同输入带有相反标签，约束就无解；即使仍然可分，一个位置异常的样本也可能把边界推向不适

合大多数数据的位置。解决办法是允许样本违反间隔要求，但把违反量计入目标。这就是**软间隔** (soft margin)：间隔仍是选择边界的依据，却不再是每个观测都必须满足的硬性条件。

为第 i 个观测引入**松弛变量** (slack variable) $\xi_i \geq 0$ ，表示其函数间隔相对于 1 的不足量。令 $\boldsymbol{\xi} = (\xi_1, \dots, \xi_n)^\top$ ，惩罚系数记为 $\lambda_s > 0$ ，以免与本章的类别数 C 混淆。标准的线性松弛惩罚形式为

$$\begin{aligned} \min_{\mathbf{w}, b, \boldsymbol{\xi}} \quad & \frac{1}{2} \|\mathbf{w}\|_2^2 + \lambda_s \sum_{i=1}^n \xi_i \\ \text{s.t.} \quad & y_i(\mathbf{w}^\top \mathbf{x}_i + b) \geq 1 - \xi_i, \\ & \xi_i \geq 0, \quad i = 1, \dots, n. \end{aligned} \quad (3.39)$$

在这个目标中， λ_s 越大，一单位间隔违反越昂贵；它惩罚的是间隔不足，而不只是错分次数。固定 $(\mathbf{w}, b)$ 后， ξ_i 越小目标越低，因而最优松弛量必为 $\max\{0, 1 - y_i g(\mathbf{x}_i)\}$ 。

当 $\xi_i = 0$ 时，样本位于规范间隔边界或其外侧；当 $0 < \xi_i < 1$ 时，样本仍被正确分类，但位于间隔内部； $\xi_i = 1$ 表示零得分； $\xi_i > 1$ 才表示落在错误一侧。图3.2固定 $g(\mathbf{x}) = x_1 - 2$ ，用同一个边界比较这几种情形。点 A 与点 B 都是正类，分别有 $y_A g(\mathbf{x}_A) = 0.5$ 和 $y_B g(\mathbf{x}_B) = -0.5$ ，所以最小松弛量分别为 0.5 与 1.5。松弛量是在得分尺度上测量的；当 $\mathbf{w} \neq \mathbf{0}$ 时，除以 $\|\mathbf{w}\|_2$ 才是沿法向方向补足至相应规范间隔边界的距离。




图 3.2 硬间隔与软间隔的教学示意，坐标无量纲。蓝圆为负类，赭方为正类；两个面板都给定 $\mathbf{w} = (1, 0)^\top$ 、 $b = -2$ ，黑色实线为决策边界 $g = 0$ ，蓝色虚线为间隔边界 $g = \pm 1$ 。单侧规范间隔为 $1/\|\mathbf{w}\|_2 = 1$ ，两虚线总宽为 $2/\|\mathbf{w}\|_2 = 2$ ；左图圈出间隔上的样本。右图红色线段直接标出松弛量：A 位于 $x_1 = 2.5$ ，正确分类但在间隔内， $\xi_A = 0.5$ ；B 位于 $x_1 = 1.5$ ，已被错分， $\xi_B = 1.5$ 。右图仅说明给定分界面下的最小松弛量，并非优化后的 SVM 最优解。

消去 ξ , 式(3.39)等价于

$$\min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|_2^2 + \lambda_s \sum_{i=1}^n \max\{0, 1 - y_i g(\mathbf{x}_i)\}. \quad (3.40)$$

其中 $\ell(z) = \max\{0, 1 - z\}$ 是**合页损失** (hinge loss): 达到目标间隔以后不再奖励更大的得分, 间隔不足时线性增加惩罚。它与前面的截断间隔损失不同, 错误一侧的损失没有截断, 因而保持凸性。这一形式把“最大间隔加违规代价”与“平方范数正则化加经验损失”联系起来。

惩罚参数的数值还依赖损失是求和还是取平均。将式(3.40)除以 $n\lambda_s$, 等价目标是平均合页损失加 $\|\mathbf{w}\|_2^2/(2n\lambda_s)$ 。所以在不同样本量或不同软件约定之间比较超参数时, 应先统一归一化方式。较大的 λ_s 允许模型付出更大范数来降低训练损失, 较小的值更重视范数控制; 是否过拟合或欠拟合还取决于数据、表示与验证结果, 不能由单个超参数独立决定。

软间隔的乘子上界来自松弛变量的最优性条件。分别为 $1 - \xi_i - y_i g(\mathbf{x}_i) \leq 0$ 与 $-\xi_i \leq 0$ 引入 $\alpha_i, \mu_i \geq 0$, 拉格朗日函数为

$$L = \frac{1}{2} \|\mathbf{w}\|_2^2 + \lambda_s \sum_i \xi_i + \sum_i \alpha_i [1 - \xi_i - y_i (\mathbf{w}^\top \mathbf{x}_i + b)] - \sum_i \mu_i \xi_i.$$

关于 $\mathbf{w}, b$ 的驻点条件仍是式(3.25), 关于每个 ξ_i 则要求

$$\lambda_s - \alpha_i - \mu_i = 0.$$

结合 $\mu_i \geq 0$, 得到 $0 \leq \alpha_i \leq \lambda_s$ 。取 $\mathbf{w} = \mathbf{0}$ 、 $b = 0$ 和所有 $\xi_i > 1$ 可以严格满足两组不等式, 因此不论数据是否可分, Slater 条件都成立。消去原始变量后有

$$\begin{aligned} \max_{\alpha} \quad & \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i,j=1}^n \alpha_i \alpha_j y_i y_j \mathbf{x}_i^\top \mathbf{x}_j \\ \text{s.t.} \quad & \sum_{i=1}^n \alpha_i y_i = 0, \\ & 0 \leq \alpha_i \leq \lambda_s, \quad i = 1, \dots, n. \end{aligned} \quad (3.41)$$

对偶可行域非空且紧, 目标连续, 所以对偶最优值可以取得。原始形式同样有最优解; 两类非空时, 限制目标的水平集可控制 $\mathbf{w}$ 与 ξ , 再由两类约束控制 b 。

软间隔的互补松弛关系多了一组:

$$\begin{aligned}\alpha_i^*(m_i^* - 1 + \xi_i^*) &= 0, \\ (\lambda_s - \alpha_i^*)\xi_i^* &= 0, \\ m_i^* &\geq 1 - \xi_i^*, \quad \xi_i^* \geq 0.\end{aligned}\tag{3.42}$$

联合原始与对偶可行性, 可以逐项读出

$$\begin{aligned}\alpha_i^* = 0 &\implies \xi_i^* = 0, \quad m_i^* \geq 1, \\ 0 < \alpha_i^* < \lambda_s &\implies \xi_i^* = 0, \quad m_i^* = 1, \\ \alpha_i^* = \lambda_s &\implies m_i^* = 1 - \xi_i^* \leq 1.\end{aligned}\tag{3.43}$$

边界上的样本可以出现在三种乘子状态中: $\alpha_i^* = 0$ 允许 $m_i^* = 1$, $\alpha_i^* = \lambda_s$ 也允许 $\xi_i^* = 0$ 且 $m_i^* = 1$ 。反过来, $m_i^* > 1$ 必有 $\alpha_i^* = 0$, $m_i^* < 1$ 必有 $\alpha_i^* = \lambda_s$, 而 $m_i^* = 1$ 时乘子可以是盒约束中的任意值, 只要整体 KKT 系统成立。达到上界的乘子因此可能对应边界点、间隔内的正确样本或错分样本, 需要结合 m_i^* 才能区分。

范数项依然只对 $\mathbf{w}$ 严格凸, 足以保证最优权重唯一, 却不能保证偏置唯一。一个简单反例是两个输入都为零, 标签分别为 +1 与 -1。此时 $\mathbf{w}^* = \mathbf{0}$, 任意 $b \in [-1, 1]$ 都使总合页损失为 2, 因此都最优。该情形也说明, 软间隔可能得到常值得分; 只有 $\mathbf{w} \neq \mathbf{0}$ 时, 才可以继续用 $1/\|\mathbf{w}\|_2$ 解释规范间隔的几何宽度。

若存在 $0 < \alpha_k^* < \lambda_s$ 的**自由支持向量** (free support vector), 它既参与决策又未碰到乘子上界, 可用 $m_k^* = 1$ 恢复偏置。若没有这种样本, 就应使用 KKT 给出的偏置区间。令 $h_i = \sum_j \alpha_j^* y_j \mathbf{K}_{j,i}$, 则 $\alpha_i^* = 0$ 要求 $y_i(h_i + b) \geq 1$, $\alpha_i^* = \lambda_s$ 要求 $y_i(h_i + b) \leq 1$ 。正标签的前一条件与负标签的后一条件给出下界, 另两种组合给出上界; 从两组界的交集中选择一个 b , 才是完整的恢复规则。该区间不一定收缩为单点。

SMO 的一元目标与误差公式不变, 但可行区间必须同时保证两个乘子都位于盒子内。令 $s = y_i y_j$, 新的 α_j 区间为

$$\begin{aligned}s = +1: \quad L &= \max\{0, \alpha_i^{(t)} + \alpha_j^{(t)} - \lambda_s\}, \\ H &= \min\{\lambda_s, \alpha_i^{(t)} + \alpha_j^{(t)}\}; \\ s = -1: \quad L &= \max\{0, \alpha_j^{(t)} - \alpha_i^{(t)}\}, \\ H &= \min\{\lambda_s, \lambda_s + \alpha_j^{(t)} - \alpha_i^{(t)}\}.\end{aligned}\tag{3.44}$$

这是由盒约束与等式约束共同截出的区间, 通常小于 $[0, \lambda_s]$ 。使用式(3.32)剪裁并回代即可; 当 $\eta = 0$ 时, 这里的区间总是有限, 可以直接比较端点目标。偏置仍按式(3.33)计算, 但优先使用更新后满足 $0 < \alpha_i < \lambda_s$ 或 $0 < \alpha_j < \lambda_s$

的样本；二者都不自由时，可暂取两个候选偏置的平均，停止时再按全体 KKT 条件核验。

在可分数据上，足够大的有限惩罚就能使软间隔与硬间隔精确对应。取任意硬间隔最优乘子 α^h ，若 $\lambda_s > \max_i \alpha_i^h$ ，则硬间隔原始解连同 $\xi = \mathbf{0}$ 、 α^h 和 $\mu_i = \lambda_s - \alpha_i^h > 0$ 满足软间隔 KKT。由强对偶它也是软间隔最优解，而且正的 μ_i 迫使所有最优松弛量为零。若数据不可分，则无论把惩罚增大到多少，都不能恢复一个本来就不存在的硬间隔可行解。

3.1.3.5 支持非线性分类（核方法）

软间隔改变对间隔违反的容忍程度，核化则把同一个间隔目标放到第1.2.1.1节定义的特征空间中。以下直接使用简介中的正定核 K ，推导分类 SVM 的对偶、预测和风险界；特征映射、核合法性与常用核见第1.2.1.2节和第1.2.1.3节。

将 $\mathbf{w} \in \mathbb{R}^d$ 换成 $\mathbf{w} \in \mathcal{H}$ ，将平方范数换成 $\|\mathbf{w}\|_{\mathcal{H}}^2$ ，软间隔原始问题的推导仍然成立。更具体地，把任意 $\mathbf{w}$ 分解为训练特征张成空间内的部分与其正交部分，后者不改变任何训练得分，却只会增加范数。因此最优权重可以限制在有限个训练特征的张成空间中；驻点条件进一步给出 $\mathbf{w}^* = \sum_i \alpha_i^* y_i \phi(\mathbf{x}_i)$ 。核化对偶于是为

$$\begin{aligned} \max_{\alpha} \quad & \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i,j=1}^n \alpha_i \alpha_j y_i y_j K(\mathbf{x}_i, \mathbf{x}_j) \\ \text{s.t.} \quad & \sum_{i=1}^n \alpha_i y_i = 0, \\ & 0 \leq \alpha_i \leq \lambda_s, \quad i = 1, \dots, n. \end{aligned} \quad (3.45)$$

在映射后严格可分的硬间隔情形，去掉乘子上界即可。新输入的得分与预测为

$$\begin{aligned} g^*(\mathbf{x}) &= \sum_{i \in S} \alpha_i^* y_i K(\mathbf{x}_i, \mathbf{x}) + b^*, \\ \hat{y}(\mathbf{x}) &= \text{sign}(g^*(\mathbf{x})). \end{aligned} \quad (3.46)$$

边界在 $\mathcal{H}$ 中仍然是线性的，在原输入空间中则可能是曲线或曲面。SMO 也只需把 $\mathbf{K}_{i,j}$ 换成 $K(\mathbf{x}_i, \mathbf{x}_j)$ ；此时 $\eta = \|\phi(\mathbf{x}_i) - \phi(\mathbf{x}_j)\|_{\mathcal{H}}^2 \geq 0$ ，前面的区间、零曲率处理与偏置更新都继续适用。

核技巧去掉了对显式特征维数的直接依赖，但没有去掉对样本量的依赖。构建完整 Gram 矩阵需要 $O(n^2)$ 次核调用，之后还要执行优化迭代；两者合起来才是训练成本。若一次核计算耗时 t_K ，单次预测的主要核计算量是 $O(|S|t_K)$ 。因此，无限维特征可以通过有限次内积运算使用，与“训练成本只由核计算决定”是两回事。

统计分析也可以沿用同一结构。若 $K(\mathbf{x}, \mathbf{x}) \leq \kappa^2$ 几乎处处，则 $\|\phi(\mathbf{x})\|_{\mathcal{H}} \leq$

κ ；将间隔风险界中的 R 换成 κ 、将权重范数换成 Hilbert 范数即可。控制的是函数范数、间隔与偏置，而不是显式坐标个数。核和超参数若由数据选择，仍需计入相应的选择代价。

3.1.3.6 支持多分类

二分类模型只需判断得分的正负；当候选类别超过两个时，还需要规定多个类别怎样竞争。硬间隔、软间隔和核方法都能作为构件，但组合多个二分类器与直接优化多类间隔会得到不同的训练目标。

现在将标签改为 $y_i \in \{1, \dots, C\}$ ，其中 $C \geq 3$ ，类别索引记为 c 。最直接的推广仍然保留二分类求解器，只改变训练任务的组织方式。**一对一** (one-vs-one, OvO) 为每对类别 $c < c'$ 训练一个分类器 $h_{c,c'}$ ，仅使用标签为 c 或 c' 的样本，共有 $C(C-1)/2$ 个模型。每个模型在这两个类别之间投一票，预测为

$$\hat{y}(\mathbf{x}) = \arg \max_{c \in \{1, \dots, C\}} \sum_{c_1 < c_2} \mathbb{1}\{h_{c_1, c_2}(\mathbf{x}) = c\}.$$

其中 $c_1, c_2 \in \{1, \dots, C\}$ ，票数并列时采用预先约定的固定规则，例如选择较小类别编号。不同类别对可能作出不相容的局部判断，投票负责把这些判断汇总成一个输出，并不要求它们对应同一个全局概率模型。

一对其余 (one-vs-rest, OvR) 为每个类别 c 构造二分类标签：原标签为 c 时取 +1，其余取 -1。训练 C 个实值得分函数 g_c 后，使用

$$\hat{y}(\mathbf{x}) = \arg \max_{c \in \{1, \dots, C\}} g_c(\mathbf{x}),$$

并固定平局规则。即使所有得分都为负，或多个类别得分为正，这个最大值规则仍能给出类别。它比较的是独立模型的得分，得分尺度与训练中的类别不平衡可能影响比较，因此通常需要统一预处理、损失约定并评估各类别的错误，而不能将这些数值直接当作互相可比的 posterior 概率。

图3.3把四个类别展开成具体训练任务。沿着一列看，一对一中的每个类别只参与三个任务；一对其余中，每个样本都参与四个任务，但只有一个任务把它标为正类。沿着一行看，前者忽略不属于当前类别对的样本，后者把所有其他类别合并为负类。这种训练标签的差异，决定了两个组合器面对的子问题并不相同。

OvO 模型多，但每个子问题只用两类样本；OvR 模型少，但每个子问题都涉及全部样本，并把一个类别与可能很大的其余类别集合比较。所以“模型数较少”不等于“总训练一定更快”。LIBSVM 的多类 SVM 使用 OvO，scikit-learn 的核分类器 `svc` 沿用这一训练方式；其输出得分的展示形状与底层实际训练了哪些二分类器是不同层面的设置。类别很多时，还应把模型存储、支持向量重复使用与预测核调用量纳入选择。




图 3.3 四分类任务中的两种二分类组合方式。各行对应一个待训练模型，各列对应样本的原类别；+1 和 -1 是为该任务重新编码的标签，点号表示该类样本不参与训练。一对一训练 6 个模型并汇总类别选票，一对其余训练 4 个模型并比较实值得分。图中给出训练与预测规则，不预设两种方法会产生相同的分类结果。

如果希望组合器能够容忍若干二分类判断错误，可以为每个类别安排一个彼此分离的编码。**纠错输出码** (error-correcting output codes, ECOC) 将类别 c 表示成长度为 q 的码字 $\mathbf{M}_{c,:}$ ，其中码本 $\mathbf{M} \in \{-1, +1\}^{C \times q}$ 的各行互不相同，每列同时含两种符号。第 j 列定义一个二分类任务，样本 i 的训练标签为 $\mathbf{M}_{y_i,j}$ ；训练后得到 q 个二分类器 h_j 。预测时形成输出码 $\mathbf{h}(\mathbf{x}) = (h_1(\mathbf{x}), \dots, h_q(\mathbf{x}))$ ，再选择最近的类别码字：

$$\hat{y}(\mathbf{x}) = \arg \min_c d_H(\mathbf{h}(\mathbf{x}), \mathbf{M}_{c,:}),$$

$$d_H(\mathbf{u}, \mathbf{v}) = \sum_{j=1}^q \mathbb{1}\{u_j \neq v_j\}. \quad (3.47)$$

这里的**汉明距离** (Hamming distance) 就是两个码字不一致的位置数。要表示 C 个不同类别，至少需要 $q \geq \lceil \log_2 C \rceil$ ；加入冗余位的目的，是增大不同类别之间的距离，而不只是增加分类器个数。Dietterich 与 Bakiri 系统研究了这种将多分类转换为多个编码位学习问题的方法²⁷。

纠错能力可以直接证明。记码本最小类间距离为 $\Delta_{\min}$ ，若真实类别为 c ，输出码与 $\mathbf{M}_{c,:}$ 相差 e 位，则对任意 $c' \neq c$ ，三角不等式给出

$$d_H(\mathbf{h}, \mathbf{M}_{c',:}) \geq d_H(\mathbf{M}_{c,:}, \mathbf{M}_{c',:}) - e \geq \Delta_{\min} - e.$$

只要 $2e < \Delta_{\min}$ ，真实码字就比其他码字更近。因此至多 $\lfloor (\Delta_{\min} - 1)/2 \rfloor$ 位错误可以被最近码字解码纠正。这个结论以实际错误位数为条件；若多个二分类器因为相同特征缺陷而同时犯错，冗余编码本身并不能保证错误位数足够小。

²⁷ T. G. Dietterich, G. Bakiri, *Solving Multiclass Learning Problems via Error-Correcting Output Codes* In Journal of Artificial Intelligence Research, 1995, vol. 2, pp. 263–286

另一条路线不再训练彼此独立的二分类器，而是直接优化类别之间的竞争关系。**Crammer-Singer 多类 SVM** (Crammer-Singer multiclass SVM) 要求真实类别得分至少比每个错误类别高一个单位间隔，从而在同一目标中学习所有类别权重。

令 $\mathbf{W} = [\mathbf{w}_1, \dots, \mathbf{w}_C] \in \mathbb{R}^{d \times C}$ ，使用带偏置的版本 $g_c(\mathbf{x}) = \mathbf{w}_c^\top \mathbf{x} + b_c$ ，相应优化问题为²⁸。

$$\begin{aligned} \min_{\mathbf{W}, \mathbf{b}, \xi} \quad & \frac{1}{2} \sum_{c=1}^C \|\mathbf{w}_c\|_2^2 + \lambda_s \sum_{i=1}^n \xi_i \\ \text{s.t.} \quad & g_{y_i}(\mathbf{x}_i) - g_c(\mathbf{x}_i) \geq 1 - \xi_i, \quad c \neq y_i, \\ & \xi_i \geq 0, \quad i = 1, \dots, n. \end{aligned} \quad (3.48)$$

不使用偏置时固定 $\mathbf{b} = \mathbf{0}$ ；使用偏置时，可加 $\sum_c b_c = 0$ 去掉共同平移的不识别性。消去松弛变量后，每个样本的损失为 $\max\{0, \max_{c \neq y_i} [1 + g_c(\mathbf{x}_i) - g_{y_i}(\mathbf{x}_i)]\}$ ，即惩罚最强错误竞争者超过允许差距的程度。预测仍取 $\arg \max_c g_c(\mathbf{x})$ ，并可将权重推广到核特征空间。

这一联合目标明确比较了类别之间的相对间隔，OvR 则分别比较“该类”与“其余类”。二者的约束数、求解器和数据分解方式不同，训练成本与预测质量也要在相同数据和调参预算下评估。联合建模提供了不同的归纳偏好，并不构成相对于 OvO 或 OvR 的普遍性能排序。

3.1.3.7 小结

SVM 的主要特点是把分类偏好写进一个明确的优化问题：表示由核决定，复杂度由范数限制，训练误差通过间隔损失进入目标。它不要求预先假设完整的类条件分布，能够用于高维特征，并通过支持向量表示保留决定边界的训练信息。文本分类可以先评估稀疏线性模型，手写字符识别可以比较线性与局部非线性核，生物序列任务则可能需要结构化核。这些应用说明可选择的表示丰富，并不意味着某个核在所有场景都有优势。

计算代价应按任务拆开估计。通用核 SVM 可能需要二次规模的核存储，优化时间受工作集策略、缓存、条件数和停止精度影响；预测成本又随支持向量数变化。线性 SVM 可以直接使用稀疏特征与专门求解器，其扩展性不能用稠密核训练的成本概括。是否适合某一数据规模，应根据实际内存、训练时间和预测延迟衡量，而不采用统一的样本量阈值。

输出含义也需要与使用目标一致。 $g(\mathbf{x})$ 是有符号的分类得分，其绝对值不等于后验概率。需要概率时，可以在未用于拟合该得分函数的校准数据上使用 **Platt 缩放** (Platt scaling)，拟合形如

$$\hat{p}(y = +1 | \mathbf{x}) = \frac{1}{1 + \exp(a_{\text{cal}} g(\mathbf{x}) + b_{\text{cal}})}$$

²⁸ K. Crammer, Y. Singer, *On the Algorithmic Implementation of Multiclass Kernel-based Vector Machines* In *Journal of Machine Learning Research*, 2001, vol. 2, pp. 265–292

的映射；也可以采用**保序回归** (isotonic regression)，在保持得分顺序的条件下学习非参数的单调概率映射。前者形状受限，后者更灵活但在校准样本较少时可能过拟合，二者都需要独立评估概率质量²⁹。

实践中也可用交叉拟合得到样本外得分来训练校准器。校准增加了一层需要数据学习的模型，并不会使原始 SVM 得分自动成为可靠概率。

回到开头的边界选择问题，SVM 给出的答案是：在约定的特征几何中，同时衡量边界的范数与样本的间隔不足。这个答案能够通过凸优化实现，也能在输入有界、范数受限和正确抽样假设下获得统计解释。真正使用时，还需共同选择特征尺度、核参数与 λ_s ，并把超参数选择、概率校准和最终测试分开。最大间隔、稀疏表示与核化分别解决不同问题；明确它们的条件，才能判断模型的表达能力、计算成本和泛化表现是否符合当前任务。

3.1.4 模型对比与总结

本小节先比较 LDA、感知机与 SVM，再介绍协方差收缩、核判别、稀疏贝叶斯和间隔参数化等代表性扩展。三种基本模型都通过线性得分比较类别，但相同的函数形式并不意味着相同的学习问题。生成式 LDA 先估计类均值、协方差和先验，再由贝叶斯法则决定边界；Fisher 判别则寻找类间散度相对于类内散度最大的投影。感知机只在违反分类条件时更新，在可分训练集上找到一个可行解；这个解依赖样本顺序，并没有被指定为最大间隔解。SVM 把间隔写进优化目标，通过范数与训练损失之间的权衡选取分类器。表3.1将这些差异放在同一组条件下比较。

模型	边界由什么决定	主要条件与代价
LDA	类均值、共享协方差与类先验	高斯假设支持概率解释；协方差估计需足够样本或正则化。
感知机	错分样本触发的权重更新	正间隔可分性支持有限更新界；不可分时需停止规则或变体。
线性 SVM	范数与间隔损失的权衡	硬间隔要求可分；软间隔需选择惩罚强度。
核 SVM	特征空间中的间隔	核定义相似性；训练与预测开销受样本数和支持向量数影响。

表 3.1 线性与核化分类器的比较。LDA 一行指共享协方差的高斯生成模型；Fisher 投影本身不要求高斯分布。各模型的理论保证分别针对估计、更新次数或风险，不能直接互换。

如果不同类别的类内变化方向和尺度明显不同，共享协方差就会限制 LDA 的表达能力。第3.1.1.1节已经定义的二次判别分析 (QDA) 保留类条件高斯假设，却为每个类别估计独立的协方差矩阵 $\hat{\Sigma}_c$ 。删去各类共同的常

²⁹ A. Niculescu-Mizil, R. Caruana, *Predicting Good Probabilities with Supervised Learning* In Proceedings of the 22nd International Conference on Machine Learning, 2005, pp. 625–632

数项后，其判别得分为

$$\begin{aligned}\delta_c(\mathbf{x}) = & \log \hat{\pi}_c - \frac{1}{2} \log \det \hat{\Sigma}_c \\ & - \frac{1}{2} (\mathbf{x} - \hat{\mu}_c)^\top \hat{\Sigma}_c^{-1} (\mathbf{x} - \hat{\mu}_c).\end{aligned}\quad (3.49)$$

任意两类得分之差含有关于 $\mathbf{x}$ 的二次项，所以边界一般是二次曲面。当协方差相同时，二次项相消，又得到 LDA。增加自由度也增加了估计负担：共享协方差模型需要 $O(d^2 + Cd)$ 个参数，QDA 则需要 $O(Cd^2)$ 个参数；每一类只有少量样本时，独立协方差容易不稳定甚至奇异。第3.4.3节将从生成分布的角度统一这两种模型。

在完全共享与完全独立之间，可以让各类借用一部分合并统计量。**正则化判别分析** (regularized discriminant analysis, RDA) 通过收缩协方差来控制这种取舍。Friedman 的原始方法包含两个调节方向：将类内协方差向合并协方差收缩，再向球形协方差收缩³⁰。记 n_c 为第 c 类样本数， $\hat{\Sigma}$ 为以 n 为分母的合并协方差。一种与原始构造相符的写法是

$$\begin{aligned}A_c(a) &= \frac{(1-a)n_c\hat{\Sigma}_c + a n \hat{\Sigma}}{(1-a)n_c + a n}, \\ \tilde{\Sigma}_c(a, b) &= (1-b)A_c(a) + b \frac{\text{tr} A_c(a)}{d} \mathbf{I}, \quad a, b \in [0, 1].\end{aligned}\quad (3.50)$$

当 $b = 0$ 时， $a = 0$ 与 $a = 1$ 分别对应 QDA 与 LDA 的协方差估计；增大 b 会减弱各方向方差差异，并在平均方差为正时帮助获得可逆估计。两个参数应在训练集内部通过验证选择。单纯在 LDA 与 QDA 之间插值，并不能在两者协方差都奇异时自动解决可逆性问题。

Fisher 判别还可以沿核方法的路线扩展。Mika 等提出的**核 Fisher 判别** (kernel Fisher discriminant, KFD) 在特征空间中重新计算类均值与散度，再最大化投影后的类间与类内散度比³¹。将投影方向写成 $\mathbf{w} = \sum_{i=1}^n a_i \phi(\mathbf{x}_i)$ ，即可把目标表达为关于系数 $\mathbf{a}$ 和核矩阵的广义 Rayleigh 商，并用正则化处理类内散度的奇异性。它与核 SVM 的区别仍在训练准则：KFD 关注整体类统计量，SVM 关注间隔及其违反程度。KFD 的基本解通常没有支持向量式的稀疏性，预测可能需要访问全部训练样本；若要从投影得分得到后验概率，还需额外建立得分分布或校准模型。

除了用间隔约束产生稀疏性，还可以为不同基函数分别学习先验的收缩强度。**相关向量机** (relevance vector machine, RVM) 采用

$$g(\mathbf{x}) = w_0 + \sum_{i=1}^n w_i K(\mathbf{x}_i, \mathbf{x}), \quad p(w_i | a_i) = \mathcal{N}(0, a_i^{-1}),$$

其中 $a_i > 0$ 是每个权重各自的先验精度，即先验方差的倒数。分类时再用适当的概率链接函数把 $g(\mathbf{x})$ 转换为类别概率。RVM 通过最大化对权重积

³⁰ J. H. Friedman, *Regularized Discriminant Analysis* In Journal of the American Statistical Association, 1989, vol. 84, no. 405, pp. 165–175

³¹ S. Mika, G. Rätsch, J. Weston, B. Schölkopf, K.-R. Müller, *Fisher Discriminant Analysis with Kernels* In Neural Networks for Signal Processing IX, 1999, pp. 41–48

分后得到的边缘似然来估计各个精度，部分 α_i 可能趋向无穷，对应权重的分布随之集中到零。在数值实现中，可以按预定的精度或贡献准则剔除相应基函数，使预测只保留一部分训练样本的基函数。有限但很大的精度只造成强收缩，并不自动把权重变成精确的零；这里的稀疏化依赖精度学习及剔除过程。Tipping 系统介绍了这一稀疏贝叶斯学习框架³²。这种做法可以输出模型内的预测分布，也不需要 SVM 的间隔惩罚参数，但仍需选择基函数并处理非凸优化。分类似然还带来近似推断的需要。相关向量在一些任务中比支持向量少，是实验观察而非普遍保证；采用贝叶斯形式也不保证概率在失配数据上自动校准。

如果希望调参时直接联系间隔错误与支持向量比例，可以考虑 ν -SVM (nu-support vector machine)。它把间隔阈值 $\rho \geq 0$ 也作为变量，在目标中用参数 ν 奖励更大的阈值，同时惩罚平均松弛量：

$$\begin{aligned} \min_{\mathbf{w}, b, \rho, \xi} \quad & \frac{1}{2} \|\mathbf{w}\|_2^2 - \nu \rho + \frac{1}{n} \sum_{i=1}^n \xi_i \\ \text{满足} \quad & y_i(\mathbf{w}^\top \phi(\mathbf{x}_i) + b) \geq \rho - \xi_i, \\ & \xi_i \geq 0, \quad \rho \geq 0. \end{aligned} \quad (3.51)$$

在最优 $\rho > 0$ 时，其对偶乘子满足 $0 \leq \alpha_i \leq 1/n$ 且 $\sum_i \alpha_i = \nu$ 。因此至少需要 νn 个非零乘子，而每个严格违反间隔的样本都占用一个达到 $1/n$ 的乘子，于是间隔错误比例不超过 ν ，支持向量比例不低于 ν 。这里的错误包括正确分类但落在间隔内的样本；结论不是测试错误率保证³³。

参数范围还受到类别比例约束。由偏置的驻点条件 $\sum_i \alpha_i y_i = 0$ ，正负两类的乘子和都为 $\nu/2$ ；若两类样本数分别为 n_+ 和 n_- ，盒约束便要求

$$0 < \nu \leq \nu_{\max} := \frac{2 \min(n_+, n_-)}{n}.$$

这里的上界不只是 $\rho > 0$ 解释所需的附加条件。若 $\nu > \nu_{\max}$ ，令 $\mathbf{w} = \mathbf{0}$ 、让常数偏置把全部样本判为多数类，并令少数类松弛量等于 2ρ 、多数类松弛量为零，就得到一条满足约束的射线；其目标值为 $(\nu_{\max} - \nu)\rho$ ，随 $\rho \rightarrow \infty$ 趋于 $-\infty$ 。因此，虽然约束集合仍非空，优化问题却无界而没有有限最优解。在允许区间内取得有限最优解后，前述比例结论仍以最优 $\rho > 0$ 为条件； $\rho = 0$ 时不能直接套用。

这些扩展分别改变了协方差的共享程度、特征空间、稀疏化机制或间隔参数化方式。实际比较时，应固定特征处理与评价口径，再判断增加的自由度能否由现有样本支持、获得的表示能力是否值得相应的计算开销。仅凭边界是直线还是曲线，无法回答这些问题。

³² M. E. Tipping, *Sparse Bayesian Learning and the Relevance Vector Machine* In *Journal of Machine Learning Research*, 2001, vol. 1, pp. 211–244

³³ B. Schölkopf, A. J. Smola, R. C. Williamson, P. L. Bartlett, *New Support Vector Algorithms* In *Neural Computation*, 2000, vol. 12, no. 5, pp. 1207–1245

3.2 基于邻域的分类

第1.2.2节的近邻计算在本节用于类别判断。与第2.2.1节平均响应不同， k -NN 分类聚合邻居的类别标签。以下保留实例，比较多数投票、距离加权与原型压缩，并分析局部类别噪声怎样影响风险；表示、尺度和检索仍按简介中的邻域约定处理。

3.2.1 k 近邻分类 (k -NN)

近邻分类的统计目标是学习类别决策，而不只是复现训练标签。Cover 与 Hart 在 1967 年的论文中回顾了 Fix 与 Hodges 始于 1951 年报告的近邻判别研究：在所研究的条件下，让近邻数随样本量增长、同时让其占比趋于零，可以获得一致性。Cover 与 Hart 则分析了始终只取一个最近邻时，极限错误率与贝叶斯风险之间的界。前者用越来越多的邻居平均标签噪声，后者刻画单个邻居仍保留多少判别信息；两者讨论的是不同的渐近设定，都不是任意有限数据集上的最优性保证³⁴。

³⁴ T. M. Cover, P. E. Hart, *Nearest Neighbor Pattern Classification* In IEEE Transactions on Information Theory, 1967, vol. 13, no. 1, pp. 21–27

3.2.1.1 模型结构

给定训练集 $D_n = \{(\mathbf{x}_i, y_i)\}_{i=1}^n$ 、距离 ρ 以及 $1 \leq k \leq n$ ，用 $N_k(\mathbf{x}) \subseteq \{1, \dots, n\}$ 表示查询 $\mathbf{x}$ 的 k 个最近邻索引。预测规则为

$$\hat{h}_{n,k}(\mathbf{x}) = \arg \max_{c \in \{1, \dots, C\}} \sum_{i \in N_k(\mathbf{x})} \mathbb{1}\{y_i = c\}. \quad (3.52)$$

距离相同时，按预先约定、独立于标签的顺序选取邻居；类别票数并列时也使用固定规则。即使 k 是奇数，多分类仍可能出现票数并列，不能省略这一约定。

式(3.52)也可以理解为估计查询附近的类别比例：

$$\hat{\eta}_{n,c}(\mathbf{x}) = \frac{1}{k} \sum_{i \in N_k(\mathbf{x})} \mathbb{1}\{y_i = c\}, \quad \hat{h}_{n,k}(\mathbf{x}) = \arg \max_c \hat{\eta}_{n,c}(\mathbf{x}). \quad (3.53)$$

比例估计解释了投票为什么可能有效：若邻域内的条件类别分布变化不大，邻居标签就能提供关于当前输入的统计证据。有限样本下，这种局部比例仍受邻域大小和噪声影响，不能仅因总和为 1 就认为已经得到准确概率。

图 3.4 固定训练点和查询，只改变参与投票的近邻数。取查询 $\mathbf{x} = (0, 0)$ ，样本 1、3、4、6 属于类 1，其余样本属于类 2。按欧氏距离计算，七个样本到查询的平方距离依编号为 1, 2, 2.5, 4.25, 5, 9, 10.25，因此编号也表示由近到远的次序。

$k = 1$ 时只有样本 1 投票，查询被判为类 1； $k = 5$ 时样本 1 至 5 投票，

其中类 1 有三票、类 2 有两票，预测仍为类 1。两幅图中的圆分别经过第 1 和第 5 个邻居，半径为 1 和 $\sqrt{5}$ 。这里改变的是当前查询使用的证据范围，圆并不是分类器在整个平面上的决策边界；由于没有给定查询的真实标签，也不能据此判断哪一个 k 更准确。




图 3.4 同一查询下的近邻范围与投票变化。教学构造取 $n = 7$ 、 $d = 2$ 、无量纲坐标和欧氏距离，查询为 $\mathbf{x} = (0, 0)$ ；两图的样本、编号及坐标尺度完全相同。蓝色圆点表示类 1，红色方点表示类 2，黄色菱形表示查询，红色虚线圆表示包含边界的近邻范围。左图 $k = 1$ 、半径 1，蓝、赭票数为 1 : 0；右图 $k = 5$ 、半径 $\sqrt{5}$ ，票数为 3 : 2，因此判为蓝色类。各邻居等权投票，距离和票数均无并列；点的位置、标签与参数均为人为设定，不代表真实数据实验。

3.2.1.2 参数学习

基本 k -NN 分类没有固定维数参数的优化过程，但需要确定输入表示、距离、近邻数及检索方式。“非参数化”是指预测关系不局限于一个固定有限维参数族；它仍有超参数，预处理和模型选择也属于学习。

距离决定哪些样本会参与投票。对数值特征，欧氏距离 $\rho(\mathbf{x}, \mathbf{z}) = \|\mathbf{x} - \mathbf{z}\|_2$ 容易计算，却会放大数值范围较大的坐标。收入和年龄共同作为特征时，直接使用原始单位会让收入差异主导距离。标准化、按业务意义设定尺度或学习特征权重都可改变这一点；不必机械地把所有特征处理成同等重要。标准化参数只能从训练集估计，交叉验证时应在各训练折内重新拟合，避免验证信息提前进入距离。

类别型特征可采用**汉明距离** (Hamming distance)，按不同取值的坐标数比较，而不能把任意类别编码的数字差当成有意义的远近。文本的 TF-IDF 等稀疏向量常比较余弦相似度，强调方向而非长度；1 减余弦相似度一般不满足三角不等式，不能直接套用所有度量空间结论。对非零向量作单位长度归一化后，按余弦相似度排序与按欧氏距离排序等价，此时可用欧氏

空间中的解释。

若特征之间相关, 可以考虑**马氏距离** (Mahalanobis distance), 用协方差调整方向上的尺度:

$$\rho_M(\mathbf{x}, \mathbf{z})^2 = (\mathbf{x} - \mathbf{z})^\top \Sigma^{-1} (\mathbf{x} - \mathbf{z}), \quad (3.54)$$

其中 $\Sigma \in \mathbb{R}^{d \times d}$ 须正定。样本不足时协方差估计可能奇异, 需要正则化; 整体协方差也不一定符合分类所需的相似性。**度量学习** (metric learning) 进一步利用标签选择距离, **大间隔最近邻** (large margin nearest neighbor, LMNN) 是其中一种方法³⁵。它学习线性变换, 拉近同类目标邻居, 并用间隔约束排开异类样本。

另一种选择是**近邻成分分析** (neighbourhood components analysis, NCA), 它对邻居选择作概率化处理, 通过提高留一预测中选中同类样本的概率学习线性变换。与只调整每个坐标尺度相比, 这类方法还能改变坐标间的组合, 但也引入额外训练目标和过拟合风险。学得的度量需要与 k 一起在未参与拟合的数据上评价, 而不能默认监督变换总会提高泛化精度³⁶。

近邻数 k 控制局部平均的范围。 $k = 1$ 时, 一个错误标签就能直接影响附近查询; 增大 k 通常能减少这种波动, 但也会把较远区域的样本混入, 从而抹平细节。这是局部估计中常见的偏差与方差取舍, 而不是零一分类风险随 k 单调变化的定律。 $k \approx \sqrt{n}$ 至多可作试验起点, 不能替代交叉验证, 更不能忽略类别比例、局部密度和距离表示。

检索代价需要区分距离计算与邻居选择。对一个 d 维稠密查询, 朴素扫描 n 个训练样本计算距离需 $O(nd)$; 若再把所有距离排序, 总代价为 $O(nd + n \log n)$ 。采用线性选择算法得到最小的 k 项, 再作投票, 可达 $O(nd + n + k)$; 使用大小为 k 的堆则需 $O(nd + n \log(k+1) + k)$ 。因此, 通常所说的 $O(nd)$ 朴素预测复杂度隐含了无需完整排序的选择方法。训练集的存储为 $O(nd)$, 大规模是否可用还取决于批量计算、硬件、精度要求和延迟预算, 不能仅由样本超过某个数量判定。

精确检索可使用 KD 树或球树 (ball tree) 等索引, 通过空间划分排除不可能更近的样本。在维数较低、分布有利时, 这些结构常能显著减少访问量, 但没有对任意数据均成立的对数查询保证, 最坏情况下仍会扫描大部分样本; “维数小于 20” 也不是适用与失效的理论分界。精确索引改变计算方式而不改变选出的邻居, 通常应按建索引成本、内存和查询时间选择。

对高维大规模数据, 还可以用**近似最近邻检索** (approximate nearest-neighbor search) 交换少量检索误差与计算收益。局部敏感哈希 (locality-sensitive hashing, LSH) 让相近向量较可能进入同一哈希桶; 分层可导航

³⁵ K. Q. Weinberger, L. K. Saul, *Distance Metric Learning for Large Margin Nearest Neighbor Classification* In Journal of Machine Learning Research, 2009, vol. 10, no. 9, pp. 207–244

³⁶ J. Goldberger, G. E. Hinton, S. T. Roweis, R. Salakhutdinov, *Neighbourhood Components Analysis* In Advances in Neural Information Processing Systems 17, 2004, pp. 513–520

小世界图 (hierarchical navigable small world, HNSW) 沿多层邻接图逐步寻找候选; 倒排文件与乘积量化 (inverted file with product quantization, IVF-PQ) 先缩小候选分区, 再用压缩编码近似距离。这些方法的搜索预算和压缩程度会改变邻居集合, 需同时检查邻居召回率与最终分类误差。以下理论以精确检索为前提, 不直接覆盖任意近似索引。

3.2.1.3 理论分析

基本 k -NN 分类不通过反复更新一组参数来拟合训练集, 因此这里的“收敛”不是优化迭代趋于某个解, 而是训练样本量 $n \rightarrow \infty$ 时, 邻居位置、条件概率估计及测试风险的渐近变化。收敛性分析先考察局部估计是否接近目标; 泛化分析再考察这些估计能够给新样本的分类错误带来什么保证。

近邻位置越来越近, 不等于邻居的标签必然等于测试标签。即使两个输入完全相同, 在有标签噪声或类别重叠时, 也可能独立产生不同标签。分析需要先确定风险对哪些随机性取平均, 再由邻居位置推到条件类别分布, 不能把三者混为一谈。

设训练样本与测试点 $(\mathbf{X}, Y)$ 独立同分布于 $\mathbb{R}^d \times \{1, \dots, C\}$, P_X 为输入边缘分布, $C \geq 2$ 。令

$$\eta_c(\mathbf{x}) = \mathbb{P}(Y = c \mid \mathbf{X} = \mathbf{x}), \quad r^*(\mathbf{x}) = 1 - \max_c \eta_c(\mathbf{x}). \quad (3.55)$$

选择后验概率最大的类别达到条件最小错误率 $r^*(\mathbf{x})$, 对输入平均得到**贝叶斯风险** (Bayes risk) $R^* = \mathbb{E}_{\mathbf{X}} r^*(\mathbf{X})$ 。给定一份训练集的测试风险, 与再对训练集平均的风险分别记为

$$L_{n,k}(D_n) = \mathbb{P}\{\hat{h}_{n,k}(\mathbf{X}) \neq Y \mid D_n\}, \quad (3.56)$$

$$R_{n,k} = \mathbb{E}_{D_n} L_{n,k}(D_n). \quad (3.57)$$

若打破距离并列采用独立随机化, 以上期望同时包含该随机化。下面的 Cover-Hart 界针对 $R_{n,1}$ 的极限, 不是任意有限 n 的风险上界, 也不是每份训练集条件风险的逐一保证。

收敛性分析 先说明足以支撑极限计算的一组分布条件。使用固定的欧氏距离, 精确寻找最近邻, 邻居选择不依赖标签; 对 P_X 几乎处处的非原子点 $\mathbf{x}$, 各 η_c 在该点相对于 P_X 的支撑集连续。所谓原子点是 $P_X(\{\mathbf{x}\}) > 0$ 的点, 它不需要这里的连续性要求。该条件不要求输入分布有密度, 更不要求每个欧氏空间位置都有正密度, 但它也不只是“条件概率存在”。

引理 3.8 最近邻风险的极限 在上述抽样、检索与连续性条件下, 最近邻位置几乎必然趋于查询位置, 并且

$$R_{1,\infty} := \lim_{n \rightarrow \infty} R_{n,1} = \mathbb{E}_X \left[1 - \sum_{c=1}^C \eta_c(\mathbf{X})^2 \right]. \quad (3.58)$$

证明. 将训练集看作同一无穷独立样本序列的前 n 项。固定支撑集中的查询 $\mathbf{x}$, 用 I_n 表示最近邻索引, 用 $B(\mathbf{x}, \varepsilon)$ 表示半径 $\varepsilon > 0$ 的开球。支撑集的定义保证该球有正概率, 因此

$$\mathbb{P}\{\|\mathbf{X}_{I_n} - \mathbf{x}\|_2 \geq \varepsilon\} = [1 - P_X(B(\mathbf{x}, \varepsilon))]^n \rightarrow 0.$$

最近邻距离随 n 不增, 对 $\varepsilon = 1, 1/2, 1/3, \dots$ 分别取极限, 即得 $\mathbf{X}_{I_n} \rightarrow \mathbf{x}$ 几乎必然成立。欧氏空间具有可数拓扑基, 不在支撑集中的点可被可数个零概率开集覆盖, 故支撑集本身具有 P_X 概率 1。若 $\mathbf{x}$ 为原子点, 训练序列几乎必然在有限步后出现 $\mathbf{x}$, 此后最近邻距离一直为零。

对非原子点, 由连续性得到 $\eta_c(\mathbf{X}_{I_n}) \rightarrow \eta_c(\mathbf{x})$; 对原子点, 这个等式最终直接成立。最近邻索引只依赖输入及与标签独立的平局约定。给定查询和所有训练输入后, 测试标签与选中的训练标签独立, 选中标签属于 c 的概率为 $\eta_c(\mathbf{X}_{I_n})$ 。故对训练集平均的条件错误率为

$$r_n(\mathbf{x}) = 1 - \sum_{c=1}^C \eta_c(\mathbf{x}) \mathbb{E}[\eta_c(\mathbf{X}_{I_n})],$$

这里的期望针对固定查询时的训练输入及邻居选择随机性。由于后验概率有界, 可用支配收敛定理得到

$$r_n(\mathbf{x}) \rightarrow r_\infty(\mathbf{x}) := 1 - \sum_{c=1}^C \eta_c(\mathbf{x})^2.$$

再利用 $0 \leq r_n(\mathbf{x}) \leq 1$, 对 $\mathbf{x}$ 积分并交换极限与期望, 就得到式(3.58)。 ■

极限中的平方项来自两次独立的类别抽取, 而不是说最近邻标签本身几乎必然收敛。位置接近保证的是选中标签的条件分布接近查询的条件分布, 单次标签抽样的波动仍然存在。

要平均掉这部分噪声, 需要让参与投票的邻居数增加; 要避免把远处结构混入, 又需要邻居只占全部训练样本的越来越小一部分。令 $k = k_n$ 满足 $k_n \rightarrow \infty$ 且 $k_n/n \rightarrow 0$ 。Stone 的非参数一致性结果在固定有限维欧氏空间中建立了近邻条件概率估计的积分收敛, 也就是对训练集与查询取平均后, 估计的绝对误差趋于零; 这为后面的风险分析提供了依据³⁷。

³⁷ C. J. Stone, *Consistent Nonparametric Regression* In The Annals of Statistics, 1977, vol. 5, no. 4, pp. 595–620

对精确欧氏近邻, 距离并列时可按与数据独立的随机排列选取, 类别票数并列时按固定类别顺序决定。对每个 c , 这样的近邻估计满足

$$\mathbb{E}_{D_n, \mathbf{X}} |\hat{\eta}_{n,c}(\mathbf{X}) - \eta_c(\mathbf{X})| \longrightarrow 0. \quad (3.59)$$

这一结论对 $\mathbb{R}^d$ 上任意固定联合分布成立, 不需要前面为简化 Cover-Hart 证明而采用的逐点连续性条件。其一般证明使用欧氏空间的覆盖性质, 不能只用一句普通大数定律代替, 因为邻居样本是根据查询和输入位置选择出来的。

在前述连续性条件下, 可以直接看出式(3.59)的两个来源。给定训练输入, 记

$$\bar{\eta}_{n,c}(\mathbf{x}) = \frac{1}{k_n} \sum_{i \in N_{k_n}(\mathbf{x})} \eta_c(\mathbf{X}_i).$$

邻居标签在给定输入后独立, 所以

$$\mathbb{E}[|\hat{\eta}_{n,c}(\mathbf{x}) - \bar{\eta}_{n,c}(\mathbf{x})| \mid \mathbf{X}_1, \dots, \mathbf{X}_n] \leq \frac{1}{2\sqrt{k_n}}.$$

上界来自 Bernoulli 变量的方差不超过 $1/4$ 及 Cauchy-Schwarz 不等式。它控制标签抽样波动。对任意有正概率的查询邻域, 落入其中的样本比例几乎必然趋向该邻域的概率; 由于 $k_n/n \rightarrow 0$, 最终会有至少 k_n 个训练样本落入其中。因此, 第 k_n 个邻居的距离趋于零。后验连续时, $\bar{\eta}_{n,c}(\mathbf{x}) - \eta_c(\mathbf{x})$ 趋于零; 在原子点, 最终选中的 k_n 个输入都可等于该点。结合有界性与支配收敛, 就得到这组较强正则性条件下的积分收敛。Stone 的结论把同一估计分析扩展到了不连续后验。

泛化分析 已有的极限计算还需要与最优分类错误比较, 才能说明近邻规则的预测保证。固定 $k = 1$ 时, Cover-Hart 定理比较引理 3.8 中的极限局部错误与最优局部错误; 让 k_n 增长时, 则可用式(3.59)控制相对于贝叶斯决策多出的错误。这两种风险保证都对训练集和独立测试点取平均。

定理 3.9 Cover-Hart 界：二分类 在引理 3.8 的条件下, 若 $C = 2$, 则

$$R^* \leq R_{1,\infty} \leq 2R^*(1 - R^*) \leq 2R^*. \quad (3.60)$$

证明. 固定 $\mathbf{x}$, 记 $p = \eta_1(\mathbf{x})$, 则 $\eta_2(\mathbf{x}) = 1 - p$, $r^*(\mathbf{x}) = \min(p, 1 - p)$ 。引理给出

$$\begin{aligned} r_\infty(\mathbf{x}) &= 1 - p^2 - (1 - p)^2 \\ &= 2p(1 - p) \\ &= 2r^*(\mathbf{x})[1 - r^*(\mathbf{x})]. \end{aligned}$$

由于 $0 \leq r^*(\mathbf{x}) \leq 1/2$, 有 $2(1 - r^*(\mathbf{x})) \geq 1$, 所以 $r_\infty(\mathbf{x}) \geq r^*(\mathbf{x})$ 。对输入取期望得到下界。对于上界,

$$\begin{aligned} R_{1,\infty} &= 2R^* - 2\mathbb{E}_{\mathbf{X}}[r^*(\mathbf{X})^2] \\ &\leq 2R^* - 2(R^*)^2 \\ &= 2R^*(1 - R^*). \end{aligned}$$

不等式利用 $\mathbb{E}[Z^2] \geq (\mathbb{E}Z)^2$, 也就是对凹函数 $2z(1 - z)$ 使用 Jensen 不等式。再用 $1 - R^* \leq 1$ 得到两倍上界。 ■

多分类时, 不能沿用二类的精确表达式 $2p(1 - p)$, 因为非最大类别的概率还可以在多个类别之间分配。需要控制的是: 固定最大后验概率以后, 其余类别的概率平方和最小能是多少。

定理 3.10 Cover-Hart 界: 多分类 在引理 3.8 的条件下, 对任意有限 $C \geq 2$,

$$R^* \leq R_{1,\infty} \leq R^* \left(2 - \frac{C}{C-1} R^* \right) \leq 2R^*. \quad (3.61)$$

证明. 固定 $\mathbf{x}$ 并简记 $r = r^*(\mathbf{x})$ 。取 c^* 使 $\eta_{c^*}(\mathbf{x}) = 1 - r$, 其余 $C - 1$ 类的概率之和为 r 。由 Cauchy-Schwarz 不等式,

$$r^2 = \left(\sum_{c \neq c^*} \eta_c(\mathbf{x}) \right)^2 \leq (C - 1) \sum_{c \neq c^*} \eta_c(\mathbf{x})^2.$$

因而

$$\begin{aligned} \sum_{c=1}^C \eta_c(\mathbf{x})^2 &\geq (1 - r)^2 + \frac{r^2}{C - 1}, \\ r_\infty(\mathbf{x}) &\leq 1 - (1 - r)^2 - \frac{r^2}{C - 1} \\ &= 2r - \frac{C}{C - 1} r^2. \end{aligned}$$

这一步的等号在其余类别的概率都等于 $r/(C - 1)$ 时成立。记 $g_C(r) = 2r - Cr^2/(C - 1)$, 它在 $0 \leq r \leq 1 - 1/C$ 上为凹函数。对输入取期望并用 Jensen 不等式,

$$R_{1,\infty} \leq \mathbb{E}_{\mathbf{X}} g_C(r^*(\mathbf{X})) \leq g_C(R^*).$$

去掉非负的二次项得到 $R_{1,\infty} \leq 2R^*$ 。另一方面, $\eta_c(\mathbf{x}) \leq 1 - r$, 故

$$\sum_{c=1}^C \eta_c(\mathbf{x})^2 \leq (1 - r) \sum_{c=1}^C \eta_c(\mathbf{x}) = 1 - r.$$

于是 $r_\infty(\mathbf{x}) \geq r$ ，积分后得到 $R_{1,\infty} \geq R^*$ 。 ■

这两个界不要求某个参数化类别分布，却仍依赖已列出的抽样和分布正则性条件。若 $R^* = 0$ ，界给出 1-NN 的期望风险趋于零；若后验概率在所有位置都为 (0.8, 0.2)，则 $R^* = 0.2$ 而 $R_{1,\infty} = 0.32$ 。后一个教学计算表明，单个近邻即使位于查询附近，也仍带有一次标签抽样的噪声，因此 1-NN 一般不能使期望风险趋于贝叶斯风险。

贝叶斯一致性 (Bayes consistency) 要求期望测试风险趋向贝叶斯风险。对于满足 $k_n \rightarrow \infty$ 且 $k_n/n \rightarrow 0$ 的近邻规则，后验估计的积分收敛已经成立；从后验估计到分类风险，还需要明确的一步。对固定查询和训练集，令 c^* 为真实后验最大的类别， $\hat{c} = \hat{h}_{n,k_n}(\mathbf{x})$ 。由于 $\hat{\eta}_{n,\hat{c}} \geq \hat{\eta}_{n,c^*}$,

$$\begin{aligned} \eta_{c^*}(\mathbf{x}) - \eta_{\hat{c}}(\mathbf{x}) &\leq |\eta_{c^*}(\mathbf{x}) - \hat{\eta}_{n,c^*}(\mathbf{x})| \\ &\quad + |\hat{\eta}_{n,\hat{c}}(\mathbf{x}) - \eta_{\hat{c}}(\mathbf{x})| \\ &\leq 2 \sum_{c=1}^C |\hat{\eta}_{n,c}(\mathbf{x}) - \eta_c(\mathbf{x})|. \end{aligned}$$

左侧就是相对于贝叶斯决策多出的条件错误率。对训练集与测试输入取期望，再使用式(3.59)和类别数有限，得到

$$R_{n,k_n} \longrightarrow R^*, \quad k_n \rightarrow \infty, \quad k_n/n \rightarrow 0. \quad (3.62)$$

这里证明的是风险期望收敛。由于 $L_{n,k_n}(D_n) - R^* \geq 0$ ，它还蕴含条件风险依概率趋于 R^* ，但不能仅据此声称每份无穷训练序列都几乎必然收敛，更不能声称预测标签对几乎每个输入最终与某个固定贝叶斯分类器完全一致。后验并列时，不同标签本来就可能达到相同最小风险；即便没有并列，逐点或几乎必然的结论也需要单独的条件与论证。

3.2.1.4 小结

k -NN 分类把预测转化为表示、距离、检索和局部投票四个相连的选择。它天然支持多分类，能够表达复杂的局部边界，也能在适当增长的邻居数下达到期望风险意义的一致性。但这些渐近结果既不提供固定样本量上的精度保证，也不为任意学习度量或近似检索自动背书。

高维问题主要在于局部邻域可能缺少足够样本，无关坐标还会削弱距离中的类别信号。在某些高维分布中，成对距离的相对差异会集中变小；这不是“所有样本距离必然相等”，也不是仅由 d 决定的普遍结论。数据的内在维数、相关结构和所用表示都很重要。文本分类、推荐、图像检索和异常检测可以借用近邻思想，其中检索或打分也不等同于本节的多数投票分类；是否适合作为系统基线，应连同检索成本和业务目标一起评价。

3.2.2 模型对比与总结

本小节先比较等权投票、距离加权与原型压缩，再介绍 LVQ、最近质心等代表性扩展。基本 k -NN 分类保存全部训练实例，并让邻居等权投票。沿着这两个选择，可以分别改变邻居的影响强度，或把训练集压缩成少量代表点。这两种改动都保留了依据邻近关系分类的思路，也可以结合使用；不过，学习代表点通常需要显式训练，因而不能把所有基于邻域的分类方法都称为“没有训练的惰性学习”。

当较远邻居会稀释近处证据时，**加权 k 近邻** (weighted k -nearest neighbors) 让不同邻居贡献不同票数：

$$\hat{h}(\mathbf{x}) = \arg \max_c \sum_{i \in N_k(\mathbf{x})} w_i(\mathbf{x}) \mathbb{1}\{y_i = c\}, \quad w_i(\mathbf{x}) \geq 0. \quad (3.63)$$

至少需要一个权重为正。Dudani 在 1976 年研究了按邻居距离范围作线性缩放的加权方案，使最近邻具有最大权重、较远邻居的权重逐渐减小³⁸。

具体地，把邻居按距离排序为 $\delta_1 \leq \dots \leq \delta_k$ ，第 r 个邻居的权重取

$$w_r = \begin{cases} \frac{\delta_k - \delta_r}{\delta_k - \delta_1}, & \delta_k > \delta_1, \\ 1, & \delta_k = \delta_1. \end{cases} \quad (3.64)$$

另一类常用选择是逆距离权重或高斯形权重 $\exp(-\delta_r^2/(2h^2))$ ，其中 $h > 0$ 控制衰减尺度。逆距离形式遇到零距离必须处理，例如只在零距离样本中投票，避免除零。距离加权可能减少远邻干扰，但也可能放大近处噪声；硬类别输出仍可能跳变，不能把加权说成必然使分类边界平滑或必然减弱对 k 的敏感性。其一致性还依赖权重不能长期集中在有限个带噪声邻居上。

若主要困难是存储全部样本，可以转向**学习向量量化** (learning vector quantization, LVQ)，用监督训练获得少量带类别的**原型向量** (prototype vector)。原型是可移动的代表点，不必等于任何一条训练记录。Kohonen 发展的 LVQ 方法为每个类别配置一个或多个原型，查询时只对这些原型作最近邻比较；它保留局部距离判别的形式，但把模型规模转为可控制的原型数量³⁹。

以基本 LVQ1 为例，设原型为 $\mathbf{m}_r \in \mathbb{R}^d$ ，类别标签为 a_r ， $r = 1, \dots, q$ 。可从各类训练样本初始化原型。每次读入 $(\mathbf{x}_i, y_i)$ ，找到最近原型 r^* ，只更新它：

$$\mathbf{m}_{r^*}^{(t+1)} = \mathbf{m}_{r^*}^{(t)} + \gamma_t s_i (\mathbf{x}_i - \mathbf{m}_{r^*}^{(t)}), \quad (3.65)$$

其中学习率 $\gamma_t > 0$ 通常随训练减小；若 $a_{r^*} = y_i$ ，取 $s_i = 1$ 把原型拉近，否则取 $s_i = -1$ 把原型推远。其余原型不动。反复遍历样本后，在验证集上选择原型数、学习率和停止时机，预测时输出最近原型的类别标签。

³⁸ S. A. Dudani, *The Distance-Weighted k -Nearest-Neighbor Rule* In IEEE Transactions on Systems, Man, and Cybernetics, 1976, vol. SMC-6, no. 4, pp. 325–327

³⁹ T. Kohonen, *Self-Organizing Maps*, Springer, 2001, 3rd ed.

当 $q \ll n$ 时, LVQ 的原型存储和朴素查询代价为 $O(qd)$, 可低于保留全部样本的近邻方法。但少量原型不一定足以表示多个分离的类内簇, 更新也受初始化和样本顺序影响。基本吸引与排斥更新是启发式过程, 不能仅凭形式类似迭代优化就声称达到全局最优, 或继承增长 k 的近邻一致性保证。

将每类限制为一个代表点, 并直接取该类样本均值, 就得到**最近质心分类器** (nearest centroid classifier)。它与 LVQ 共同使用原型距离, 但不需要通过吸引与排斥来训练。令 $n_c = \sum_{i=1}^n \mathbb{1}\{y_i = c\} > 0$, 则

$$\mu_c = \frac{1}{n_c} \sum_{i: y_i = c} \mathbf{x}_i, \quad (3.66)$$

$$\hat{h}(\mathbf{x}) = \arg \min_c \|\mathbf{x} - \mu_c\|_2^2. \quad (3.67)$$

预测是在全部 C 个类原型中作一次最近邻选择。训练计算均值需 $O(nd)$, 存储和单次查询需 $O(Cd)$ 。

第4.1.1节的 K-means 也用均值作为质心, 但还要在没有类别标签时估计簇分配; 最近质心分类器直接按已知类别分组计算均值, 目标是预测预设类别。相同的质心计算因标签条件不同而承担不同任务。

最近质心的两个类别区域由两质心的等距面分开, 所以欧氏距离下的两类边界是超平面。若真实类条件分布为具有共同球形协方差的高斯分布、先验概率又相等, 用真实均值作最近质心决策就是贝叶斯规则; 这是一组充分条件, 不是它能够使用的必要条件。类别多峰、尺度差异很大或均值被异常值牵动时, 一个质心会丢失重要的几何结构。

在文本分类中, 类质心方法常与 Rocchio 联系起来。Rocchio 于 1971 年研究的相关反馈通过相关与不相关文档调整查询向量, 后来的 Rocchio 分类把类别的文档均值作为原型, 将这一思想用于没有查询向量的类别判别。文本表示还可以对文档及原型作归一化, 改用余弦相似度, 所得分类边界需按具体归一化方式理解⁴⁰。

等权近邻保留较多局部信息, 加权近邻调整这些信息的影响, LVQ 和最近质心则用更紧凑的代表点换取存储与查询效率。压缩越强, 对类内几何形态的限制通常越大, 但推理开销不再必然随 n 线性增长。判断这些方法是否合适, 应同时看距离是否保留类别关系、原型能否覆盖类内结构, 以及独立测试上的误差, 而不能只按“保留实例多”或“原型少”作选择。

⁴⁰ C. D. Manning, P. Raghavan, H. Schütze, *Introduction to Information Retrieval*, Cambridge University Press, 2008

3.3 基于树与规则的分类

沿用第1.2.3节的条件分支, 分类树在叶节点输出类别或类别比例。以下比较分类任务怎样选择分裂、控制生长并确定叶输出; 原始结构之外的规则学习则放在同一节中, 便于对照条件共享、覆盖与冲突处理。

沿用训练集 $D_n = \{(\mathbf{x}_i, y_i)\}_{i=1}^n$, 其中输入有 d 个特征, $y_i \in \{1, \dots, C\}$ 。本节允许特征是数值型或类别型, 用 $D \subseteq D_n$ 表示到达某个节点的训练样本。建树需要同时确定测试特征、阈值或取值分组, 以及叶节点的输出, 并非只估计一组预先固定的数值参数。常见做法是在当前节点选择一个能改善类别划分的测试, 再递归处理各个子集; 为避免把偶然差异也变成分支, 还要限制生长或在生长后**剪枝** (pruning), 即删除缺少预测收益的子树。

图 3.5 把同一个分类器分别画成区域和条件树。在 $[0, 1]^2$ 内, $x_1 \leq 0.5$ 的输入直接判为类 1; 其余输入继续检查 x_2 , 不超过 0.55 时判为类 2, 否则判为类 1。左图的水平分界只出现在右半区域, 正对应右图中第二次测试只对第一个条件不成立的输入执行。这说明树中的路径不仅记录有哪些条件, 也规定条件在哪个区域生效。




图 3.5 二维分类的教学构造。左图为归一化特征空间 $[0, 1]^2$ 中的区域划分, 圆点表示类 1, 方点表示类 2; 右图为产生同一划分的条件树。根节点检查 $x_1 \leq 0.5$, 仅在其“否”分支上继续检查 $x_2 \leq 0.55$ 。点的位置与分裂阈值均为人为设定, 不代表真实数据实验。

不同树算法的主要差异落在三个问题上: 怎样评价一次分裂, 允许什么样的分支结构, 怎样控制树的大小。ID3 提供了信息增益驱动的基本构造, C4.5 扩展其评分和数据处理方式; CART 则采用统一的二叉划分与子树选择框架, 形成了另一条决策树研究路线。

3.3.1 ID3

要决定先检查哪个特征, 需要比较“检查前还分不清多少类别”和“检查后还分不清多少类别”。ID3 (Iterative Dichotomiser 3) 据此选择特征, 再在各分支上重复同一过程。Quinlan 在 1986 年的论文中将 ID3 追溯到 Hunt 等人的概念学习系统 (Concept Learning System, CLS): CLS 向前考察若干层候选树, 按测量与误分类代价选择测试; ID3 则改用信息驱动的局部评价。这一变化把建树中的“先测什么”落实为当前节点上可计算的信息增益比较, 并不保证整棵树最优。本节采用以离散特征、信息增益和不作后剪枝为设定的基本 ID3⁴¹。

⁴¹ J. R. Quinlan, *Induction of Decision Trees In Machine Learning*, 1986, vol. 1, no. 1, pp. 81–106

3.3.1.1 模型结构

在节点样本集 D 上, 记 $p_c(D)$ 为类别 c 的样本比例。**熵** (entropy) 用一个数概括类别分布的不确定性: 节点只含一类时为零, 各类越均匀, 熵越大。采用以 2 为底的对数,

$$H(D) = - \sum_{c=1}^C p_c(D) \log_2 p_c(D), \quad (3.68)$$

其中约定 $0 \log_2 0 = 0$ 。对第 j 个离散特征, 令 V_j 为其可能取值集合, $D_{j,v} = \{(\mathbf{x}_i, y_i) \in D : x_{i,j} = v\}$ 。该特征的**信息增益** (information gain) 是分裂前后熵的减少量:

$$\text{Gain}(D, j) = H(D) - \sum_{v \in V_j} \frac{|D_{j,v}|}{|D|} H(D_{j,v}). \quad (3.69)$$

空子集对求和的贡献定义为零。这里必须按子集大小加权, 否则只有一个样本的小分支会与包含大部分样本的分支同样重要。

ID3 用选中的特征建立一个内部节点, 每个取值对应一个分支。叶节点保存到达该处的类别计数, 并通常输出多数类; 类别计数相同时使用预先固定的平局规则。这样得到的是分段常值分类器: 同一叶区域内的所有输入具有相同预测。叶节点也可报告类别频率, 但少量样本上的频率不应被直接理解为可靠的概率估计。

3.3.1.2 参数学习

从根节点的 D_n 出发, 算法计算所有可用特征的信息增益, 选择最大者, 再分别对其子集递归建树。离散特征已经按取值完全展开后, 同一路径上不必再次使用它。若当前样本全部同类, 就生成该类叶节点; 若可用特征耗尽而标签仍不一致, 就输出当前多数类。对训练时未出现的分支, 可以保留以父节点多数类为输出的回退叶节点, 使预测规则对新输入仍有定义。

每次选择只依据当前节点, 因而这是**贪心搜索** (greedy search): 接受眼前收益最大的分裂, 不回头枚举所有可能的整棵树。基本 ID3 不在建树后再作剪枝; 限制最大深度、最小叶样本数或最小增益, 属于另外加入的生长控制。尤其是“增益为零就停止”也会改变基本搜索行为: 在异或关系中, 单个特征的增益可能为零, 而连续两次测试可以完全分开类别。停止规则既能减少无效分裂, 也可能阻止发现特征交互。

3.3.1.3 小结

信息增益把分裂选择变成了可计算的局部比较, 却有**多值偏差** (multivalued attribute bias): 取值很多的特征更容易把训练样本分成纯净的小组。若每条记录的编号都不同, 用编号分裂会使所有子节点熵为零, 增益达到

$H(D)$ ，但对一个新编号几乎没有帮助。再加上基本 ID3 缺少后剪枝，训练集中的噪声也可能变成专门的叶节点。

ID3 因此适合说明树怎样从样本中长出来，却不能仅凭训练误差小就获得泛化保证。接下来的 C4.5 分别处理评分偏差、输入类型和树的规模，保留的仍是这种递归划分思想。

3.3.2 C4.5

让决策树用于含连续数值和缺失字段的数据，除了换一个分裂分数，还需要约定阈值怎样选择、未知值怎样传递、哪些枝条应当删除。Quinlan 在 1993 年的专著中给出了 C4.5 的完整程序体系。它沿用 ID3 的递归构造，同时加入增益率、连续特征测试、缺失值处理、错误估计剪枝和规则提取⁴²。

⁴² J. R. Quinlan, *C4.5: Programs for Machine Learning*, Morgan Kaufmann, 1993, 1st ed.

3.3.2.1 模型结构

多值特征容易得到大增益，是因为它本身就把数据切得很细。C4.5 用**信息增益率** (gain ratio) 比较“类别信息的增加”与“产生这些分支所需的划分信息”。设测试 a 把 D 分成 $D_1, \dots, D_b$ ，令 $q_v = |D_v|/|D|$ ，则

$$\text{SplitInfo}(D, a) = - \sum_{v=1}^b q_v \log_2 q_v, \quad (3.70)$$

$$\text{GainRatio}(D, a) = \frac{\text{Gain}(D, a)}{\text{SplitInfo}(D, a)}. \quad (3.71)$$

这里的信息增益仍按式(3.69)计算，只把按特征取值划分替换为测试 a 的各个结果。分母为零意味着没有真正划分，不能参与比值比较。

归一化并未消除所有问题。若某个测试只分离出极少数样本，其划分信息也很小，微小的增益可能被除法放大。因此，C4.5 不是在所有测试中直接取增益率最大者，而是先计算候选测试的平均信息增益，只在增益不低于该平均值的测试中比较增益率。这个筛选避免纯粹依靠小分母取胜；它是启发式约束，并不保证每次都选中最有泛化价值的特征。

3.3.2.2 参数学习

离散特征可以按取值作多路分裂；连续特征则使用 $x_j \leq t$ 与 $x_j > t$ 的二路测试。候选阈值来自排序后相邻不同取值之间，且分裂后必须满足最小子节点样本量等限制。连续特征在某次分裂后仍可在后代节点使用，因为同一数值轴上可能需要多个阈值。

C4.5 各版本对阈值的评价略有区别。较早版本按增益率选择阈值；Quinlan 在 1996 年的修订中先按信息增益选择连续特征的阈值，再扣除搜索阈值所需的描述长度代价，参与特征之间的增益筛选和增益率比较。若有 q

个候选切分位置，这项逐样本惩罚形如 $\log_2 q/|D|$ ，用来抵消“可试阈值更多”带来的选择优势。算法 3.3 突出这些版本共有的建树骨架，把阈值评价留在候选测试生成步骤中⁴³。

算法 3.3 C4.5 的递归生长与后剪枝

输入： 节点样本 D ，可用特征集合 F ，停止及剪枝设置

输出： 剪枝后的分类树

```

1: function GROW( $D, F$ )
2:   if  $D$  全部同类，或样本量不足，或  $F$  为空 then
3:     return 以  $D$  中多数类为输出的叶节点
4:   end if
5:   生成各特征的有效测试，连续特征同时选择阈值
6:   计算各测试的增益；缺失值按正文约定处理
7:   if 没有有效测试，或最大增益不为正 then
8:     return 以  $D$  中多数类为输出的叶节点
9:   end if
10:  求候选测试的平均增益  $\bar{g}$ 
11:  保留增益不低于  $\bar{g}$  且划分信息为正的测试
12:  选择其中增益率最大的测试  $a$ ，建立节点  $T$ 
13:  for 测试  $a$  的每个结果  $v$  do
14:    得到相应的子集  $D_v$  及子问题的特征集合  $F_v$ 
15:    if  $D_v$  为空 then
16:      将  $D$  的多数类叶节点接到分支  $v$ 
17:    else
18:      将 GROW( $D_v, F_v$ ) 接到分支  $v$ 
19:    end if
20:  end for
21:  return  $T$ 
22: end function
23:  $T \leftarrow \text{GROW}(D, F)$ 
24: 自底向上比较子树与简化方案的悲观错误估计
25: return 剪枝后的  $T$ 

```

缺失值不能简单地当作已知测试结果。设测试 a 的已知样本总权重占当前节点的比例为 q_{known} 。C4.5 在这些已知样本上估计类别熵的下降，再乘 q_{known} 降低证据不足的测试所得收益；划分信息还计入未知部分的比例。选定测试后，把缺失该特征的样本按已知样本进入各分支的比例作分数权重分配。后续熵、类别计数和多数类都相应使用权重。预测时遇到缺失值，也按分支权重综合子树的类别预测，而不是随意选一条路径。

树生长完成后，C4.5 采用**悲观错误剪枝** (pessimistic error pruning)：训练误差倾向于低估新样本错误，因而以二项错误计数的上置信估计作修正，比较保留子树与折叠成多数类叶节点的估计错误数。若简化方案不差，就可以删除该子树；完整实现还可考察用某个子树提升替代当前分支。

⁴³ J. R. Quinlan, *Improved Use of Continuous Attributes in C4.5* In *Journal of Artificial Intelligence Research*, 1996, vol. 4, pp. 77–90

置信设置控制剪枝强度，但这种在自适应建树后使用的错误估计是模型选择启发式，不能直接当作整棵树泛化误差的严格置信保证。

树也可以转成规则：每条根到叶路径的测试构成规则前件，叶类别作为后件，再尝试删除不必要条件并筛选规则。未经简化的路径规则继承树的区域划分；条件删除以后可能产生重叠，因此规则系统还必须规定冲突处理和默认预测。这种转换并非只把树的文字抄成一份无序清单。

3.3.2.3 小结

C4.5 对 ID3 的扩展相互配合：增益筛选和增益率调整局部测试的比较，阈值及缺失值机制扩大可处理的数据范围，后剪枝和规则简化控制最终结构的复杂度。它适合需要检查预测条件的任务，但实际可读性仍取决于树深、规则数和特征含义。单棵树与支持向量机或提升树谁更准确，需要在相同数据划分和调参预算下比较，不能仅由算法名称决定。

3.3.3 CART

另一种组织树的方法是把每次测试都限定成二选一，再统一研究大树中应保留哪些子树。**分类与回归树**（classification and regression trees, CART）采用这一框架；Breiman、Friedman、Olshen 与 Stone 在 1984 年的专著中将树的构造、最优剪枝与统计性质放在同一体系中讨论。其中，代价复杂度剪枝把“怎样长出一棵大树”与“最终保留多大的子树”分开：生长阶段比较局部分裂，剪枝阶段形成候选子树序列，再用验证选择规模。因此，CART 与 ID3 的区别不只是换一个不纯度指标，还涉及分支结构与整树选择。这里关注分类树；第 2.3.1 节的回归 CART 复用递归二分与代价复杂度剪枝，但按响应损失选择分裂并在叶内输出数值，本节则按类别不纯度或误分类代价分裂并输出类别标签或类别比例⁴⁴。

⁴⁴ L. Breiman, J. H. Friedman, R. A. Olshen, C. J. Stone, *Classification and Regression Trees*, Wadsworth International Group, 1984, 1st ed.

3.3.3.1 模型结构

CART 分类树通常用**基尼不纯度**（Gini impurity）评价节点中类别的混杂程度：

$$G(D) = 1 - \sum_{c=1}^C p_c(D)^2. \quad (3.72)$$

它也等于从节点经验类别分布独立抽取两个标签时，两者不同的概率。对于产生左右子集 D_L 和 D_R 的测试 a ，比较

$$\Delta G(D, a) = G(D) - \sum_{v \in \{L, R\}} \frac{|D_v|}{|D|} G(D_v). \quad (3.73)$$

基尼与熵都鼓励子节点变纯，但并不总给出相同的排序。基尼省去了对数运算，也不意味着整个训练必然更快，因为阈值搜索和数据访问可能占用

更多时间。

对连续特征，二分测试仍是阈值比较；对类别特征，测试可写成 $x_j \in S$ 与 $x_j \notin S$ ，其中 S 是部分取值组成的集合。寻找这个集合本身也是搜索问题，取值很多时不能假定枚举所有分组都很便宜。统一的二叉结构便于遍历和剪枝，但可能用多层测试表达一棵多路树的一次分裂。

3.3.3.2 参数学习

生长阶段反复选择基尼下降最大的有效二分测试，直到满足生长限制，得到一棵较大的树 T_0 。随后进行**代价复杂度剪枝** (cost-complexity pruning)：不再逐个比较局部增益，而是在 T_0 的候选子树中平衡拟合误差和叶节点数。令 $L(T)$ 为树 T 的叶节点集合， $\hat{c}_\ell$ 为叶 ℓ 的预测类别，定义

$$\hat{R}(T) = \frac{1}{n} \sum_{\ell \in L(T)} \sum_{(x_i, y_i) \in D_\ell} \mathbb{1}\{y_i \neq \hat{c}_\ell\}, \quad (3.74)$$

$$J_\alpha(T) = \hat{R}(T) + \alpha |L(T)|, \quad \alpha \geq 0. \quad (3.75)$$

这里 $\hat{R}(T)$ 采用全训练集上的误分类比例，使不同子树的误差具有共同尺度。有些软件把叶不纯度的加权和作为剪枝代价；使用其参数时需要核对具体定义，而不能混用不同尺度的 α 。

剪枝路径可以由**最弱环节剪枝** (weakest-link pruning) 生成。设内部节点 t 以下的子树为 T_t ，把它折叠成一个叶节点后，该区域对全训练集误差的贡献为 $\hat{R}(t)$ ；保留时贡献为 $\hat{R}(T_t)$ 。两种方案的代价相等时，

$$\alpha_t = \frac{\hat{R}(t) - \hat{R}(T_t)}{|L(T_t)| - 1}. \quad (3.76)$$

分子是折叠后增加的训练错误，分母是删去的叶数，因而 α_t 衡量“每少保留一个叶节点要付出多少误差”。剪去最小 α_t 对应的分支，再重新计算，就得到从大树到根叶节点的嵌套序列。若某些分支增加叶数却不降低误分类率，可先在 $\alpha = 0$ 时合并；临界值处可能有多个最优子树，按一致的最小子树约定处理平局。

对每个 α ，上述序列包含相应的最优剪枝子树，但最优性仅限于给定 T_0 的子树，不是所有可能决策树。实际需要用验证集或交叉验证选择 α ；交叉验证时，各训练折都应独立生长和剪枝，不能先用全体数据确定结构，再把同一结构放入各验证折评分。

3.3.3.3 小结

把叶节点多数类换成数值均值，把分类不纯度换成平方误差，就得到平方损失下的回归树构造；不需要另换一种树的表示。随机森林常采用这种二叉树，梯度提升方法也常用回归树拟合更新方向。不过，提升树的分裂目

标可能来自所用损失的梯度与曲率，不能一概说成直接运行原始 CART 分类算法。

CART 的经典框架还讨论了**替代分裂**（surrogate split），即主测试特征缺失时，寻找能够尽量复现主分裂结果的其他特征测试。类别权重和误分类代价也能改变生长与叶预测。具体软件未必实现全部机制；例如 scikit-learn 的决策树采用优化的 CART 框架，但类别特征编码和缺失值行为须以相应版本接口为准。二叉结构方便实现，不会自动消除噪声、类别不平衡或数据漂移带来的困难。

3.3.4 规则分类与 RIPPER

在分类任务中，规则的结论是类别标签。第1.2.3节已介绍规则与树的表示差别；这里采用有序规则，预测由首次命中的类别及默认类决定，训练则需要同时处理条件增长、剪枝与覆盖。

逐条学习规则时，一个直接困难是：为了覆盖少量例外，不断增加条件会产生庞大的规则集；过早删去条件，又可能丢失有用的局部结构。早期的 AQ 系列探索了从样本归纳条件规则的路线，后来的规则学习把覆盖策略与误差控制结合起来。Fürnkranz 与 Widmer 在 1994 年提出**增量减错剪枝**（incremental reduced error pruning, IREP），将单条规则的增长和立即剪枝嵌入逐条学习过程，以避免先生成庞大规则集再统一简化的开销⁴⁵。

Cohen 在 1995 年改进 IREP 的剪枝评分和停止准则，并加入整组规则的反复优化，形成 RIPPER（Repeated Incremental Pruning to Produce Error Reduction）。其核心不是保证找到全局最优规则，而是在规则长度、覆盖范围和错误之间进行可承受的启发式搜索。下面分别说明增长、剪枝、覆盖和优化在这一过程中承担什么作用⁴⁶。

3.3.4.1 模型结构

RIPPER 输出有序规则以及一个默认类别 c_0 。第 r 条规则的前件可写为

$$a_r(\mathbf{x}) = \bigwedge_{j=1}^{m_r} b_{r,j}(\mathbf{x}), \quad a_r(\mathbf{x}) \implies y = c_r, \quad (3.77)$$

其中 $b_{r,j}$ 是一个返回真或假的测试， m_r 为该规则的条件数。例如， $x_1 > 60$ 与 $x_2 =$ 是 可以组成一个合取，但每个测试的业务含义必须由特征定义决定。规则**覆盖**（cover）样本，指样本满足其前件，与样本真实标签是否等于后件无关。

若规则数为 s ，预测时寻找最小的 $r \in \{1, \dots, s\}$ 使 $a_r(\mathbf{x})$ 成立，输出 c_r ；不存在这样的 r 时输出 c_0 。二分类中，可以为目标类学习若干规则，把另一类作为默认类。多分类时，经典 RIPPER 通常按类别出现频率由低到高

⁴⁵ J. Fürnkranz, G. Widmer, *Incremental Reduced Error Pruning* In Machine Learning Proceedings 1994, 1994, pp. 70–77

⁴⁶ W. W. Cohen, *Fast Effective Rule Induction* In Machine Learning Proceedings 1995, 1995, pp. 115–123

学习，逐次区分当前类与尚待区分的其他类，把最常见类放在默认位置。这种类别排序有助于为少数类显式生成规则，但不构成少数类召回率的保证。

3.3.4.2 参数学习

RIPPER 采用**顺序覆盖** (sequential covering)：在尚未被前面规则覆盖的工作集上学习一条规则，加入有序列表后，再处理没有命中的记录。设当前目标类别为 c_+ ，属于该类的记录称为正例，其余为负例。保留原始二类训练集 $D^{(0)}$ 用于整体评分，另用 U 表示不断缩小的覆盖工作集。区分这两个对象很重要：从 U 移除一条被错误覆盖的负例，并不是把这个错误从模型评价中抹去。

学习单条规则时，先分层随机划分增长集与剪枝集，经典设置约为 2 : 1。增长从空前件开始，空前件覆盖所有样本；每次添加一个测试，使前件更严格、覆盖范围更小。测试可直接使用连续特征的阈值，无须一律在训练前离散化。Cohen 的实现对缺失特征采用保守约定：涉及该特征的测试在缺失记录上不成立，因此规则需要其他已知字段来覆盖这些记录。

增长时使用源自 FOIL (First Order Inductive Learner) 的信息增益评分。设加入条件前覆盖 p_0 个正例、 q_0 个负例，加入后覆盖 p_1 个正例、 q_1 个负例，其中 q 不表示全章的样本量 n 。在命题规则设定下，评分为

$$g = p_1 \left(\log_2 \frac{p_1}{p_1 + q_1} - \log_2 \frac{p_0}{p_0 + q_0} \right). \quad (3.78)$$

括号比较加入条件前后的正例纯度，外面的 p_1 避免只看纯度而忽略保留下来的正例数。候选条件必须保留正例并满足覆盖量等实现约束；增长通常持续到不再覆盖增长集负例，或没有可接受的改进条件。不可分的噪声样本可能使前一种停止情形无法达到，算法不能为追求绝对纯净而无限增长。

剪枝则允许把规则末端的一串条件一起删掉，也就是比较增长过程中得到的各个前缀，而非只尝试删去一个条件。若某个前缀在剪枝集覆盖 p 个正例、 q 个负例，RIPPER 的基本评分是

$$v = \frac{p - q}{p + q}, \quad p + q > 0. \quad (3.79)$$

在分母为正时，它与覆盖样本中的正确率 $p/(p+q)$ 给出相同排序。剪枝选择评分最好的可接受前缀，平局可偏向较短者；覆盖不到剪枝样本时，分数没有定义，需要回退或拒绝，而不能擅自记成满分。这一评分改变了原 IREP 对规则的偏好，尤其避免单凭覆盖大量样本而认可纯度不足的条件。

单条规则看起来合理，也可能使整组规则过于复杂。**最小描述长度** (minimum description length, MDL) 把这种取舍表达为：用多少比特写下规则，

再用多少比特说明规则预测错了哪些训练标签。记有序规则集为 $\mathcal{R}$ ，总描述长度可概括为

$$L_{\text{total}}(\mathcal{R}; D^{(0)}) = L_{\text{rules}}(\mathcal{R}) + L_{\text{errors}}(D^{(0)} | \mathcal{R}). \quad (3.80)$$

第二项按完整规则集及默认类计算，因而仍包含误覆盖记录。Cohen 的实验允许总长度暂时超过此前的最小值，但超过 64 比特就停止增加规则，再从后向前删除会增加总长度的规则。64 是实现中的停止设置，不是统计定理给出的常数，也不要求每次加规则都立即缩短总长度。

算法 3.4 给出二类子问题的主要流程。伪代码中的增长和剪枝采用前述评分，描述长度的编码细节由具体实现确定；多分类时在外层加入类别排序与默认类约定。

算法 3.4 RIPPER 的覆盖学习与规则优化

```

输入： 二类样本  $D^{(0)}$ ，目标类  $c_+$ ，优化轮数  $b$ 
输出： 有序规则集  $\mathcal{R}$  及默认负类
1:  $\mathcal{R} \leftarrow ()$ 
2: function EXTEND( $\mathcal{R}, D^{(0)}$ )
3:    $U \leftarrow D^{(0)}$  中未被  $\mathcal{R}$  覆盖的样本
4:    $L_{\min} \leftarrow L_{\text{total}}(\mathcal{R}; D^{(0)})$ 
5:   while  $U$  中仍有正例 do
6:     将  $U$  分层随机划为增长集  $G$  和剪枝集  $P$ 
7:     从空前件增长规则  $a$ ，按式(3.78)添加条件
8:     在  $P$  上按式(3.79)选择  $a$  的前缀
9:     if 无可接受规则，或  $a$  不覆盖  $U$  中的任何正例 then
10:      停止本轮覆盖学习
11:     end if
12:     把  $a \Rightarrow c_+$  追加到  $\mathcal{R}$ 
13:      $L \leftarrow L_{\text{total}}(\mathcal{R}; D^{(0)})$ 
14:      $L_{\min} \leftarrow \min(L_{\min}, L)$ 
15:     if  $L > L_{\min} + 64$  then
16:      停止本轮覆盖学习
17:     end if
18:     从  $U$  移除被  $a$  覆盖的全部样本，包括正例和负例
19:   end while
20:   从后向前删除能使总描述长度降低的规则
21:   return  $\mathcal{R}$ 
22: end function
23:  $\mathcal{R} \leftarrow \text{EXTEND}(\mathcal{R}, D^{(0)})$ 
24: for  $t = 1, \dots, b$  do
25:   for 按顺序考察  $\mathcal{R}$  中的每条规则 do
26:     从空前件生成替代规则，从原前件生成修订规则
27:     剪枝候选规则时，评价完整规则集在剪枝集上的错误

```

```

28:      用总描述长度在原规则、替代规则、修订规则之间选择
29:  end for
30:   $\mathcal{R} \leftarrow \text{EXTEND}(\mathcal{R}, D^{(0)})$ 
31: end for
32: return  $\mathcal{R}$ , 无规则匹配时预测负类

```

优化阶段是在整组规则的上下文中改写单条规则。替代规则从空前件重新增长，修订规则在原前件上继续添加条件；对候选规则的剪枝不只看它自身的纯度，还看替换后完整有序规则集的错误。随后用 MDL 选择保留原规则还是采用候选，必要时重新进行规则删除和剩余正例的覆盖学习。原论文把一次优化称为 RIPPER，重复两次称为 RIPPER2；优化次数是可配置的搜索预算，不能解释为已经完成全局最优化。

3.3.4.3 小结

RIPPER 适合需要按条件讨论预测的场景，例如审阅异常交易或核查业务规则。增长提供局部区分能力，留出剪枝降低对增长集偶然细节的依赖，覆盖避免重复处理已经命中的输入，MDL 与规则优化限制整体复杂度。这些机制控制过拟合风险，但不保证在任意噪声和样本量下都得到短而准确的规则。

连续特征可由阈值直接处理；多分类和类别不平衡也不能简单归为“不支持”或“能力弱”。真正需要检查的是少数类能否在增长集与剪枝集中获得足够样本、类别排序是否合适，以及使用总体错误率会不会忽略重要的漏报。规则变多、条件变长和重叠变复杂时，预测与人工审阅的成本都会上升，不能仅凭规则形式就认为模型已经满足可审计要求。

3.3.5 模型对比与总结

本小节先比较 ID3、C4.5 与 CART，再介绍改变分裂检验、工程实现或叶模型的代表性扩展。表 3.2 按同一组问题比较三种基本方法。C4.5 的主要变化是补充分裂评分、输入处理和错误估计，CART 则把二叉结构与一条可验证选择的剪枝路径结合起来。两者都不能保证找到泛化误差最小的树，因而不能把一种剪枝准则描述成对另一种的无条件优越替代。

方法	分裂评分	基本分支形式	规模控制
ID3	信息增益	离散取值多路分裂	基本版本无后剪枝
C4.5	增益筛选与增益率	离散多路、连续阈值二分	悲观错误估计剪枝
CART	基尼不纯度下降	统一二叉分裂	代价复杂度路径及验证选择

表 3.2 三种决策树在基本分类设定下的比较。输入支持和停止细节随实现版本变化。

沿着 C4.5 的程序体系, C5.0 进一步改进树与规则生成的实现, 并加入提升集成、样本权重、误分类代价和特征筛选等功能⁴⁷。提升集成反复学习多个分类器, 改变后续学习对样本的关注, 再组合各分类器的输出; AdaBoost 是这一序贯加权路线的代表构造⁴⁸。解释集成预测时, 需要同时考察多个模型。样本权重表示不同训练记录的重要性, 误分类代价则区分不同错误的损失, 使训练目标能够反映实际决策中的代价差异。RuleQuest 提供商业版本和 GPL 源码版本, 其公开实验报告了特定数据与硬件条件下的速度及内存改进; 实际收益随数据规模、输出树还是规则集等设置变化。

若关注的不仅是类别变纯, 还包括分裂是否有足够的统计证据, 可以采用 Kass 于 1980 年提出的**卡方自动交互检测** (chi-square automatic interaction detection, CHAID)。它对类别特征的取值与标签建立列联表, 先合并类别分布差异不显著的取值, 再比较各特征与响应的关联, 按经过多重比较调整的检验结果选择分裂; 证据不足时停止。剩下的取值组形成多路分支, 适合把分群结果读作交叉分类, 但连续变量通常需要先分组, 分组方式会影响结果。这里的显著性针对相应检验的关联假设, 既不是因果证据, 也不能直接作为全树不出错的保证⁴⁹。

信息增益和基尼下降还面临另一种偏差: 候选切分越多, 越容易偶然找到一个高分切分。**条件推断树** (conditional inference tree, CTree) 把“选哪个特征”与“在该特征上怎样切分”分开。Hothorn、Hornik 与 Zeileis 在 2006 年的框架中用条件置换分布评价特征与响应的关联: 先检验当前节点中所有特征均与响应无关联的全局原假设; 不能拒绝时停止, 否则选择检验证据最强的特征, 再为它寻找二分位置。通过同一检验尺度和多重检验控制, 可以缓解不同取值数目带来的选择偏差⁵⁰。

CTree 的统计解释有明确边界。置换检验依赖相应原假设下的可交换性, 渐近近似的可靠程度又受样本量影响; 若标签与单个特征都不相关、只通过交互发生联系, 节点检验也可能停止。检验驱动的生长控制为是否继续分裂提供依据, 但不等于对所有分布都严格控制泛化误差, 或保证小样本任务一定优于经过验证的其他树。

也可以保留树的区域划分, 却改变叶节点如何预测。**逻辑模型树** (logistic model tree, LMT) 在每个叶区域内使用 Logistic 回归, 即用特征的线性得分表示类别对数几率, 再转成类别概率。这样, 树负责不同区域之间的结构变化, 叶模型负责区域内部随特征变化的概率。Landwehr、Hall 与 Frank 的 2005 年期刊论文基于其 2003 年会议工作, 通过 LogitBoost 逐步拟合逻辑模型, 并在后代节点继续细化祖先模型, 而不是把每个小叶中的模型都完全独立地从零估计⁵¹。

例如在二分类叶区域 ℓ 内, LMT 可输出

$$\hat{p}_{\ell}(y = 1 | \mathbf{x}) = \frac{1}{1 + \exp[-(\mathbf{w}_{\ell}^T \mathbf{x} + b_{\ell})]}, \quad (3.81)$$

⁴⁷ RuleQuest Research, *Is See5/C5.0 Better Than C4.5?*, Feb. 2017, URL: <https://www.rulequest.com/see5-comparison.html> (visited on 10/02/2026)

⁴⁸ Y. Freund, R. E. Schapire, *A Decision-Theoretic Generalization of On-Line Learning and an Application to Boosting* In Journal of Computer and System Sciences, 1997, vol. 55, no. 1, pp. 119–139

⁴⁹ G. V. Kass, *An Exploratory Technique for Investigating Large Quantities of Categorical Data* In Journal of the Royal Statistical Society. Series C (Applied Statistics), 1980, vol. 29, no. 2, pp. 119–127

⁵⁰ T. Hothorn, K. Hornik, A. Zeileis, *Unbiased Recursive Partitioning: A Conditional Inference Framework* In Journal of Computational and Graphical Statistics, 2006, vol. 15, no. 3, pp. 651–674

⁵¹ N. Landwehr, M. Hall, E. Frank, *Logistic Model Trees* In Machine Learning, 2005, vol. 59, no. 1-2, pp. 161–205

其中 $\mathbf{w}_\ell \in \mathbb{R}^d$ 和 $b_\ell \in \mathbb{R}$ 是叶模型的系数。概率在单个叶区域内部平滑变化，但跨越不同叶的边界时仍可能跳变，也不自动具有良好的校准性质。模型拟合、迭代次数选择和树剪枝共同增加训练成本，解释时也要同时阅读路径条件与叶模型系数。

这些变种分别改变分裂证据、实现或叶模型。对树结构波动的进一步处理放在第3.5节；此处的比较仍针对单棵分类树。

本小节先比较树与 RIPPER 的条件组织方式，再介绍单特征规则、束搜索和决策表等代表性扩展。树与规则的差别主要是条件如何共享，以及训练时怎样寻找这些条件。树在一个节点上的分裂同时决定多个分支，适合复用共同的前置判断；直接规则学习一次寻找一个局部区域，不要求不同区域具有相同的判断顺序。两者都要反复搜索，树并不是“一次训练就完成”而规则才需要迭代。若若干类别区域共享长前缀，树可能更紧凑；若局部条件各不相同，扁平规则可以避免为维持树结构而复制分支。

复杂规则学习是否真的必要，可以用只看一个特征的方法作比较。**单特征规则** (one rule, OneR) 对每个候选特征建立“取值到多数类”的映射，再选择训练错误最少的特征。这里的“one”指一个特征：具有多个取值的特征通常对应多条 if-then 规则。连续特征需要形成带有最小样本量约束的区间，防止每个数值都单独成组。Holte 在 1993 年的研究发现，在所考察的常用基准数据上，单特征规则与更复杂学习器的预测表现并不总有很大差距。这为使用简单基线检验任务难度提供了实证依据，但具体结论仍受所选数据集限制⁵²。

示例 3.11 一个特征可以产生多条规则 构造一个含 10 个样本的二分类训练集。特征 A 有 a, b, c 三个取值，对应的“类 1、类 2”计数分别为 (3, 1)、(1, 2) 和 (0, 3)。按每组多数类预测，得到三条规则： $A = a$ 时判为类 1， $A = b$ 或 $A = c$ 时分别判为类 2，训练错误数为 $1+1+0 = 2$ 。另一个二值特征 B 的两组计数均为 (2, 3)，其单特征映射的错误数为 $2+2 = 4$ 。OneR 在这两个候选中选择 A ，得到的是一个特征上的三条取值规则。新记录出现未见取值时，仍需要预先约定多数类回退等处理方式。

若一个特征不够，又希望在条件搜索中保留多种可能，可以采用 Clark 与 Niblett 于 1989 年提出的 CN2。它结合 AQ 的规则覆盖思想与类似 ID3 的纯度评价，用**束搜索** (beam search) 寻找条件合取：每轮扩展已有候选，只保留评分最好的 b 个候选继续搜索，其中 b 为束宽。相较于只保留一个候选，束搜索能探索更多路径，但被舍弃的条件仍可能属于最优规则，因此并不保证避开局部最优。CN2 还用显著性筛选限制偶然形成的纯净小区域⁵³。

原始 CN2 学习有序规则，Clark 与 Boswell 在 1991 年的改进中进一步

⁵² R. C. Holte, *Very Simple Classification Rules Perform Well on Most Commonly Used Datasets In Machine Learning*, 1993, vol. 11, no. 1, pp. 63–90

⁵³ P. Clark, T. Niblett, *The CN2 Induction Algorithm In Machine Learning*, 1989, vol. 3, no. 4, pp. 261–283

研究了无序规则：针对类别分别生成条件，允许多个规则共同参与预测。有序规则以首次命中解决冲突；无序规则则需要组合匹配规则的类别分布或投票权重。无序表示减少了对单一顺序的依赖，却把解释负担转移到重叠和冲突处理上，因此规则学习和预测时的聚合约定需要配套选择⁵⁴。

规则还可以组织成查找表。**决策表**（decision table）选择一个特征子集 $S \subseteq \{1, \dots, d\}$ ，把训练样本在这些特征上的取值组合作为键，保存同键样本的多数类。训练的难点主要转向选择 S ：特征太少会把不同类别混在一起，特征太多又使组合稀疏、难以匹配新样本。Kohavi 在 1995 年研究了通过特征子集搜索学习决策表的方法，使用验证误差评价候选组合；最佳优先搜索不断扩展当前较好的候选子集，并在若干次扩展没有改善时停止，而不是保证遍历全部子集⁵⁵。

决策表通常只保存训练中实际出现的组合，不必枚举所有理论上可能的取值。连续值需要离散化或另外约定匹配方法，未出现的组合可回退到训练多数类。在哈希索引下，查表本身可以很快，但还要读取并构造包含 $|S|$ 个特征的键，特征搜索的训练代价也不能忽略。它适合可用少量离散字段表达的决策；若类别由复杂交互决定，表会变大，且相近却不完全相同的输入不能自动共享统计证据。

OneR 限制使用的特征数，CN2 扩大条件搜索范围，RIPPER 交替覆盖、剪枝和优化，决策表则共享一组索引特征。这些方法是在不同位置限制模型复杂度，不是一条规则越来越细就必然越来越准确的路线。选择时应同时检查独立验证误差、规则规模、未匹配输入和冲突处理；只有这些行为都明确，规则形式才真正有助于使用和审阅。

⁵⁴ P. Clark, R. Boswell, *Rule Induction with CN2: Some Recent Improvements In Machine Learning—EWSL-91*, 1991, pp. 151–163

⁵⁵ R. Kohavi, *The Power of Decision Tables In Machine Learning: ECML-95*, 1995, pp. 174–189

3.4 基于概率的分类

第1.2.4节已区分直接建立条件类别概率与先描述类条件输入分布的两条路线。本节分别用 Logistic 回归、朴素贝叶斯和 GDA 说明参数估计、类别决策与概率检验。沿用训练集 D_n ，类别数为 C 、类别索引为 c ； p 按观测类型表示概率质量函数或概率密度。LDA 的共享协方差推导见第3.1.1节，这里直接在一般高斯模型族中使用该结果。

3.4.1 Logistic 回归

若直接用实值线性函数拟合 0/1 标签，输出可能小于零或大于一，不能直接解释为概率。**Logistic 回归**（logistic regression）保留线性得分，却通过一个有界变换把它映射为正类概率。这里将二分类标签约定为 $\{0, 1\}$ ；名称中的“回归”描述对概率与特征关系的建模，任务仍是分类。

第2.1.5节把伯努利分布、logit 链接与其他响应模型统一在广义线性模型中；本节复用这套条件概率结构，但进一步规定类别决策阈值与误判代

价，并单独检查概率校准。

Logistic 曲线的历史早于统计分类。Verhulst 在 1838 年用它描述受增长上限约束的人口变化，后来这一曲线进入生物测定和二值响应分析。从增长曲线到统计回归，函数保留了相同形式，变量与参数的解释却发生了变化；Cramer 对这一发展过程作了专门考证⁵⁶。

3.4.1.1 模型结构

记 $p(\mathbf{x}) = \mathbb{P}(y = 1 | \mathbf{x})$ 。比值 $p(\mathbf{x})/[1 - p(\mathbf{x})]$ 称为**几率** (odds)，衡量正类相对于负类的可能性。对它取对数得到**对数几率** (log-odds，也称 logit)，其取值可以覆盖整个实数轴，因而适合与线性得分连接：

$$\log \frac{p(\mathbf{x})}{1 - p(\mathbf{x})} = \mathbf{w}^\top \mathbf{x} + b. \quad (3.82)$$

其中 $\mathbf{w} \in \mathbb{R}^d$ 是权重， $b \in \mathbb{R}$ 是偏置。令右侧为 z ，由 $p/(1 - p) = e^z$ 整理出 $p = e^z/(1 + e^z)$ ，便得到

$$p(\mathbf{x}) = \sigma(\mathbf{w}^\top \mathbf{x} + b), \quad \sigma(z) = \frac{1}{1 + e^{-z}}. \quad (3.83)$$

这个 S 形函数称为**Sigmoid 函数** (sigmoid function)，此处特指 Logistic 形式。它把任意有限得分转成严格介于零和一之间的数。Cox 在 1958 年的二值序列回归研究是这一统计建模路线的经典文献⁵⁷。

参数的解释落在对数几率尺度上：保持其他特征不变， x_j 增加一个单位，正类几率乘以 e^{w_j} 。概率本身的变化还取决于原来的概率，因为

$$\frac{\partial p(\mathbf{x})}{\partial x_j} = w_j p(\mathbf{x})[1 - p(\mathbf{x})].$$

因此， w_j 的正负说明模型中的影响方向，大小却不能脱离特征单位直接比较，也不自动具有因果含义。例如，假设某特征的 $w_j = \log 2$ ，原来正类概率为 $1/2$ ，该特征增加一单位后概率变为 $2/3$ ，而不是增加固定的 $\log 2$ 。

在两类误判代价相同时，以 $p(\mathbf{x}) \geq 1/2$ 预测正类，边界就是 $\mathbf{w}^\top \mathbf{x} + b = 0$ 。若误报的代价为 $a > 0$ 、漏报为 $r > 0$ ，正确分类代价为零，则预测正类的条件是 $a[1 - p(\mathbf{x})] \leq rp(\mathbf{x})$ ，即阈值改为 $a/(a + r)$ 。这一决策解释要求输入概率足够可靠；合法的数值范围本身还不能保证这一点。

图3.6把概率阈值与得分阈值放在同一条曲线上比较。一般地，概率阈值 $\tau \in (0, 1)$ 对应得分阈值 $\log[\tau/(1 - \tau)]$ 。在图中的教学设定下，误报与漏报代价相等时取 $\tau = 0.5$ ；若改成 $a = 4$ 、 $r = 1$ ，则 $\tau = 0.8$ ，得分至少达到 $\log 4 \approx 1.386$ 才预测正类。曲线本身没有改变，改变的是把概率转成类别的规则。

⁵⁶ J. S. Cramer, *The Origins of Logistic Regression*, Discussion Paper 2002-119/4, Tinbergen Institute, 2002

⁵⁷ D. R. Cox, *The Regression Analysis of Binary Sequences* In Journal of the Royal Statistical Society: Series B (Methodological), 1958, vol. 20, no. 2, pp. 215–232




图 3.6 线性得分 $z = \mathbf{w}^T \mathbf{x} + b$ 经 Logistic 函数转为正类概率 p 。蓝色实线为 $p = \sigma(z)$ ；红色虚线与圆点标出 $(0, 0.5)$ ，黄色点划线与方点标出 $(\log 4, 0.8)$ 。两组辅助线分别连接概率阈值与对应的得分阈值，数值是教学构造，不表示训练或校准结果。

3.4.1.2 参数学习

对独立样本，模型给出的标签概率为 $p_i^{y_i}(1-p_i)^{1-y_i}$ ，其中 $p_i = \sigma(\mathbf{w}^T \mathbf{x}_i + b)$ 。

最大似然估计 (maximum likelihood estimation, MLE) 选择使已观察标签最可能出现的参数。其条件对数似然为

$$\ell(\mathbf{w}, b) = \sum_{i=1}^n [y_i \log p_i + (1 - y_i) \log(1 - p_i)]. \quad (3.84)$$

最大化 ℓ 等价于最小化负对数似然 $L = -\ell$ ，也就是二分类**交叉熵损失** (cross-entropy loss)：给真实标签分配的概率越低，惩罚越大。令增广输入 $\tilde{\mathbf{x}}_i = (\mathbf{x}_i^T, 1)^T$ 、参数 $\boldsymbol{\beta} = (\mathbf{w}^T, b)^T \in \mathbb{R}^{d+1}$ ，并记 $z_i = \tilde{\mathbf{x}}_i^T \boldsymbol{\beta}$ ，可写成

$$L(\boldsymbol{\beta}) = \sum_{i=1}^n [\log(1 + e^{z_i}) - y_i z_i]. \quad (3.85)$$

数值计算不宜先求极端概率再取对数，可用 $\log(1 + e^z) = \max\{0, z\} + \log(1 + e^{-|z|})$ 避免指数溢出。

为确定更新方向，利用 $\sigma'(z) = \sigma(z)[1 - \sigma(z)]$ 求导。令 $\tilde{\mathbf{X}} \in \mathbb{R}^{n \times (d+1)}$ 的第 i 行为 $\tilde{\mathbf{x}}_i^T$ ， $\mathbf{p} = (p_1, \dots, p_n)^T$ 、 $\mathbf{y} = (y_1, \dots, y_n)^T$ ，则

$$\begin{aligned} \nabla L(\boldsymbol{\beta}) &= \tilde{\mathbf{X}}^T (\mathbf{p} - \mathbf{y}), \\ \nabla^2 L(\boldsymbol{\beta}) &= \tilde{\mathbf{X}}^T \mathbf{R} \tilde{\mathbf{X}}, \\ \mathbf{R} &= \text{diag}(p_i(1 - p_i))_{i=1}^n. \end{aligned} \quad (3.86)$$

梯度中的 $p_i - y_i$ 是预测概率与观察标签的差。对任意 $\mathbf{v} \in \mathbb{R}^{d+1}$ ，Hessian

的二次型为

$$\mathbf{v}^\top \nabla^2 L \mathbf{v} = \sum_{i=1}^n p_i(1-p_i)(\tilde{\mathbf{x}}_i^\top \mathbf{v})^2 \geq 0.$$

所以负对数似然 L 是凸函数，而被最大化的 ℓ 是凹函数。有限参数处的 $p_i(1-p_i) > 0$ ；若 $\tilde{\mathbf{X}}$ 列满秩， L 严格凸，否则可能存在不改变训练得分的平坦方向。这涉及**可识别性** (identifiability)：数据能否区分不同参数。即使严格凸，也只能保证有限极小点若存在便唯一，不能保证它一定存在。

例如，若存在 β_0 使 $(2y_i - 1)\tilde{\mathbf{x}}_i^\top \beta_0 > 0$ 对所有样本成立，沿 $t\beta_0$ 令 $t \rightarrow \infty$ ，每项损失均趋于零，但任意有限 t 的损失仍大于零。完全分离的数据因此没有有限 MLE；准完全分离也可能使部分参数发散。完整的存在性分析区分分离、准分离和重叠情形，不能仅凭凸性断言“唯一全局最优解”⁵⁸。

实际训练常加入 $\lambda \|\mathbf{w}\|_2^2/2$ ，其中 $\lambda > 0$ 。这个 L_2 惩罚抑制权重无限增大，也改善病态方向的数值条件。若两类均有样本，所有权重都受惩罚而偏置不受惩罚，所得二分类目标仍有唯一有限极小点；但若训练集只有一类，偏置仍可独自趋于无穷。若连偏置也作正的二次惩罚，则整个增广参数方向都受约束。使用 $\lambda \|\mathbf{w}\|_1$ 可得到稀疏权重，但目标不再处处可微，不能直接套用下面的光滑牛顿更新。

求解器的选择取决于数据规模和存储成本。稠密数据的一轮完整梯度计算为 $O(nd)$ ，构造 Hessian 约为 $O(nd^2)$ ，直接分解又需要 $O(d^3)$ 。若存储 $d \times d$ 量级的 Hessian 过于昂贵，**有限内存拟牛顿法** (limited-memory BFGS, L-BFGS) 只保留少量历史更新来近似二阶信息。大规模稀疏数据则可采用**随机梯度下降** (stochastic gradient descent, SGD)，每次用一个样本或小批量近似完整梯度。选择时还应考虑稀疏程度和精度要求，而不是固定的样本数门槛。

数据持续到达时，也可以增量更新模型。McMahan 等人的点击率系统使用稀疏正则与在线优化，展示了 Logistic 回归在大规模预测中的工程用途⁵⁹。增量训练省去了每次从头拟合的成本，但持续更新能否改善未来预测，仍取决于更新规则和数据变化。

对于中小规模问题，**迭代重加权最小二乘** (iteratively reweighted least squares, IRLS) 把牛顿步改写为一个权重随当前预测变化的最小二乘问题。令 $\mathbf{J} = \text{diag}(1, \dots, 1, 0)$ ，使偏置不受惩罚。在第 t 步计算

$$\begin{aligned} u_i^{(t)} &= z_i^{(t)} + \frac{y_i - p_i^{(t)}}{p_i^{(t)}(1-p_i^{(t)})}, \\ \beta^{(t+1)} &\in \arg \min_{\beta} \left\{ \frac{1}{2} \sum_{i=1}^n \mathbf{R}_{i,i}^{(t)} (u_i^{(t)} - \tilde{\mathbf{x}}_i^\top \beta)^2 + \frac{\lambda}{2} \beta^\top \mathbf{J} \beta \right\}. \end{aligned} \quad (3.87)$$

⁵⁸ A. Albert, J. A. Anderson, *On the Existence of Maximum Likelihood Estimates in Logistic Regression Models* In *Biometrika*, 1984, vol. 71, no. 1, pp. 1–10

⁵⁹ H. B. McMahan, G. Holt, D. Sculley, M. Young, D. Ebner, J. Grady, L. Nie, T. Phillips, E. Davydov, D. Golovin, S. Chikkerur, D. Liu, M. Wattenberg, A. M. Hrafnkelsson, T. Boulos, J. Kubica, *Ad Click Prediction: A View from the Trenches* In *Proceedings of the 19th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 2013, pp. 1222–1230

这里的 $\mathbf{u}_i^{(t)}$ 是供当前二次近似使用的工作响应，不是新标签。对应正规方程为

$$(\tilde{\mathbf{X}}^\top \mathbf{R}^{(t)} \tilde{\mathbf{X}} + \lambda \mathbf{J}) \boldsymbol{\beta}^{(t+1)} = \tilde{\mathbf{X}}^\top \mathbf{R}^{(t)} \mathbf{u}^{(t)}.$$

将 $\mathbf{u}^{(t)}$ 代入即可还原“当前参数减去 Hessian 逆作用于梯度”的牛顿步。实现时应解线性方程而不显式求逆，并用阻尼或线搜索控制更新；当 p_i 接近零或一时，直接计算工作响应可能不稳定，可改用梯度与 Hessian 求牛顿方向。停止条件可综合梯度范数、目标变化与最大迭代次数，牛顿法的局部快速收敛不意味着从任意初始化都可无阻尼运行⁶⁰。

⁶⁰ T. Hastie, R. Tibshirani, J. Friedman, *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*, Springer, 2009, 2nd ed.

3.4.1.3 支持多分类 (Softmax)

新闻主题等任务要求在 C 个互斥类别中选择一个，不能把每一类都当成互不相关的二分类输出。**Softmax 回归** (softmax regression, 也称 multinomial logistic regression) 同时建立各类得分，并将它们转成总和为一的概率；它保留的是“任意两类的对数概率比为线性函数”这一结构。

模型结构。为每类引入 $\mathbf{w}_c \in \mathbb{R}^d$ 和 $b_c \in \mathbb{R}$ ，令 $z_c(\mathbf{x}) = \mathbf{w}_c^\top \mathbf{x} + b_c$ 。其后验模型为

$$p_c(\mathbf{x}) = \mathbb{P}(y = c | \mathbf{x}) = \frac{\exp z_c(\mathbf{x})}{\sum_{r=1}^C \exp z_r(\mathbf{x})}. \quad (3.88)$$

指数保证概率为正，分母保证归一化；两类之间的分母相消，得到

$$\log \frac{p_c(\mathbf{x})}{p_r(\mathbf{x})} = (\mathbf{w}_c - \mathbf{w}_r)^\top \mathbf{x} + b_c - b_r.$$

当 $C = 2$ 时， $p_1(\mathbf{x}) = \sigma((\mathbf{w}_1 - \mathbf{w}_2)^\top \mathbf{x} + b_1 - b_2)$ 。把第 1 类视为正类、第 2 类视为负类，就回到二分类 Logistic 回归。

共同增加得分不会改变概率。更具体地，对任意 $\mathbf{a} \in \mathbb{R}^d$ 和 $t \in \mathbb{R}$ ，变换 $\mathbf{w}_c \mapsto \mathbf{w}_c + \mathbf{a}$ 、 $b_c \mapsto b_c + t$ 使每个指数项同乘 $\exp(\mathbf{a}^\top \mathbf{x} + t)$ ，因而全部约掉。这是 $d + 1$ 维的参数冗余。选择第 C 类为**参考类** (reference class)，就是把该类完整的增广参数固定为零：

$$\begin{aligned} \mathbf{w}_C &= \mathbf{0}, & b_C &= 0, \\ \log \frac{p_c(\mathbf{x})}{p_C(\mathbf{x})} &= \mathbf{w}_c^\top \mathbf{x} + b_c \quad (c < C). \end{aligned} \quad (3.89)$$

仅固定 $\mathbf{w}_C$ 而不固定 b_C 不够。类似地， $\lambda \sum_c \|\mathbf{w}_c\|_2^2 / 2$ 能够消除共同权重平移的自由，却不能锁定共同偏置平移；仍须约束偏置，例如令 $\sum_c b_c = 0$ ，或惩罚全部偏置。消除这种固有冗余后，还应检查训练设计矩阵的秩与数据分离，不能把这些不同问题混为一谈。

参数学习。现在 $y_i \in \{1, \dots, C\}$ ，记 $p_{i,c} = p_c(\mathbf{x}_i)$ ， $\boldsymbol{\Theta} \in \mathbb{R}^{(d+1) \times C}$ 的第 c 列

为 $\beta_c = (\mathbf{w}_c^\top, b_c)^\top$ 。多类负对数似然是

$$\begin{aligned} L(\Theta) &= - \sum_{i=1}^n \log p_{i,y_i} \\ &= \sum_{i=1}^n \left[\log \sum_{c=1}^C e^{z_c(\mathbf{x}_i)} - z_{y_i}(\mathbf{x}_i) \right]. \end{aligned} \quad (3.90)$$

以 $\mathbb{1}\{\cdot\}$ 表示条件成立时为一、否则为零的指示函数，梯度为

$$\begin{aligned} \nabla_{\mathbf{w}_c} L &= \sum_{i=1}^n [p_{i,c} - \mathbb{1}\{y_i = c\}] \mathbf{x}_i, \\ \frac{\partial L}{\partial b_c} &= \sum_{i=1}^n [p_{i,c} - \mathbb{1}\{y_i = c\}]. \end{aligned} \quad (3.91)$$

它仍由“预测减观察”的残差驱动。Hessian 的 (c, r) 参数块为

$$\nabla_{\beta_c, \beta_r}^2 L = \sum_{i=1}^n p_{i,c} [\mathbb{1}\{c = r\} - p_{i,r}] \tilde{\mathbf{x}}_i \tilde{\mathbf{x}}_i^\top.$$

对任意增广参数扰动 $\mathbf{v}_c$ ，令 $\mathbf{a}_{i,c} = \tilde{\mathbf{x}}_i^\top \mathbf{v}_c$ ，相应二次型为

$$\sum_{i=1}^n \left[\sum_{c=1}^C p_{i,c} a_{i,c}^2 - \left(\sum_{c=1}^C p_{i,c} a_{i,c} \right)^2 \right] \geq 0.$$

方括号正是以 $\mathbf{p}_i$ 为权重的方差，故 L 凸。共同平移使方差为零，秩亏还会引入其他平坦方向；分离数据上同样可能不存在有限 MLE。参考类约束解决表示冗余，适当正则化控制参数大小，两者的作用不同。

Softmax 可用分块牛顿法、L-BFGS 或小批量 SGD 优化，多类 Hessian 还包含类别间的耦合，不能简单把 C 个独立的二分类 IRLS 问题拼起来。求概率时应先减去 $m(\mathbf{x}) = \max_c z_c(\mathbf{x})$ ，用 $e^{z_c - m} / \sum_r e^{z_r - m}$ 得到完全相同且更稳定的结果。普通稠密实现的一轮梯度计算约为 $O(ndC)$ 。

类别特别多时，分母求和也会成为瓶颈。**层次 Softmax** (hierarchical softmax) 以树上路径概率的乘积替代平坦分类参数化；**噪声对比估计** (noise-contrastive estimation, NCE) 通过区分数据与人为噪声来估计模型；**负采样** (negative sampling) 只对抽取的负例建立局部区分目标。三者都可减少某些计算，但不能统称为原 Softmax 似然的等价计算，尤其负采样通常改变了训练目标⁶¹。

决策与概率语义。预测可取 $\hat{y}(\mathbf{x}) = \arg \max_c p_c(\mathbf{x}) = \arg \max_c z_c(\mathbf{x})$ ，并按固定类别次序处理平局。Softmax 输出已经满足概率公理，却不自动满足**概率校准** (probability calibration)：在被预测为某类概率约为 0.8 的样本中，该类的实际比例也应接近 0.8。有限样本、模型失配、正则化和分布

⁶¹ I. Goodfellow, Y. Bengio, A. Courville, *Deep Learning*, MIT Press, 2016

变化都可能破坏这种对应。

Softmax 常用作神经网络的分类输出层，但其归一化也不能保证整个网络校准。Guo 等对现代网络的实验表明，分类准确与置信度可靠可以明显分离；独立验证数据上的温度缩放等方法能改善一些设置下的校准，却仍不是任意新分布下的保证⁶²。

3.4.1.4 小结

Logistic 回归把线性得分、条件概率与代价敏感阈值连接起来，多类版本则用 Softmax 联合比较各类。固定特征表示下的训练目标凸，便于优化与复核；权重也可在对数几率尺度上解释。但可识别性、有限解的存在性和概率校准分别需要检查，不能从“凸目标”或“概率输出”一并推出。

它的表示限制来自线性对数几率：若需要非线性交互，应显式加入交叉项或其他特征变换。训练可通过随机优化增量进行，预测则只需保存参数并计算得分。信用评分、医学风险预测和点击率预估都可以采用这种基线，但具体特征与验证方式需要对应到各自任务。

3.4.2 朴素贝叶斯

若希望通过“哪一类更可能产生当前输入”来分类，就需要估计类条件分布。困难在于， d 个二值特征已有 2^d 种组合，逐一统计需要大量样本。**朴素贝叶斯** (naive Bayes, NB) 把复杂的联合分布拆成较小的分布，用简化假设换取少量统计量和直接的参数估计。这样的约束可能降低有限样本下的估计波动，也可能引入持续的模型偏差，并不无条件提高精度。

Maron 在 1961 年关于自动索引的研究，是概率方法用于文档归类的早期工作之一。文档分类需要从大量词项中提取可累积的类别证据，这也成为朴素贝叶斯的一项典型用途⁶³。

3.4.2.1 模型结构

对一般特征向量，NB 采用给定类别后的**条件独立** (conditional independence) 假设：已知 $y = c$ 后，一个特征的取值不再改变其他特征的分布。令 $\pi_c = \mathbb{P}(y = c)$ 、 $p_{j,c}(x_j) = p(x_j | y = c)$ ，模型写成

$$q_c(\mathbf{x}) = \prod_{j=1}^d p_{j,c}(x_j),$$

$$\mathbb{P}_{\text{NB}}(y = c | \mathbf{x}) = \frac{\pi_c q_c(\mathbf{x})}{\sum_{r=1}^C \pi_r q_r(\mathbf{x})}. \quad (3.92)$$

记号 q_c 强调这是模型使用的乘积分布，未必等于真实类条件分布。条件独立不要求全部训练样本混在一起时特征仍独立，例如词项之间的总体相

⁶² C. Guo, G. Pleiss, Y. Sun, K. Q. Weinberger, *On Calibration of Modern Neural Networks* In Proceedings of the 34th International Conference on Machine Learning, 2017, pp. 1321–1330

⁶³ M. E. Maron, *Automatic Indexing: An Experimental Inquiry* In Journal of the ACM, 1961, vol. 8, no. 3, pp. 404–417

关性可能部分来自主题差异。

只需要分类时，各类共同的分母可以省略。为避免许多小概率连乘下溢，通常比较对数得分

$$s_c(\mathbf{x}) = \log \pi_c + \sum_{j=1}^d \log p_{j,c}(x_j), \quad \hat{y}(\mathbf{x}) = \arg \max_c s_c(\mathbf{x}). \quad (3.93)$$

这里 s_c 不是归一化的对数后验；需要概率时还须减去 $\log \sum_r e^{s_r}$ 。零概率可使得分为负无穷，后面的平滑正是为未见事件保留概率质量。文档的多项式版本沿用相似得分，但它的独立性对象是词元位置，而非总长度固定后的各维计数，必须另外说明。

3.4.2.2 参数学习

令 $n_c = \sum_i \mathbb{1}\{y_i = c\}$ ，类先验的 MLE 为 $\hat{\pi}_c = n_c/n$ 。这是以训练样本的类别比例估计目标总体的比例，依赖抽样具有代表性；若训练集人为重采样，不能未经修正就把重采样后的比例当成部署先验。也可以使用有依据的外部类别比例；若希望保留对该比例的不确定性，并为训练中未见的类别保留概率质量，则可对类概率向量 $\boldsymbol{\pi} = (\pi_1, \dots, \pi_C)^\top$ 设置参数先验。以下对类别概率与各组类条件参数设置相互独立的先验，以便分别更新。

狄利克雷分布 (Dirichlet distribution) 就是定义在概率向量上的分布：其取值满足 $\pi_c \geq 0$ 、 $\sum_c \pi_c = 1$ ，这一区域称为概率单纯形。给定参数 $\gamma_c > 0$ ，先验在单纯形内部的密度与各坐标的幂次乘积成正比。独立类别观测的似然也具有相同形式，因此

$$\begin{aligned} p(\boldsymbol{\pi}) &\propto \prod_{c=1}^C \pi_c^{\gamma_c-1}, \\ p(y_1, \dots, y_n | \boldsymbol{\pi}) &\propto \prod_{c=1}^C \pi_c^{n_c}, \\ p(\boldsymbol{\pi} | y_1, \dots, y_n) &\propto \prod_{c=1}^C \pi_c^{\gamma_c+n_c-1}. \end{aligned}$$

后验仍是狄利克雷分布，只需把参数从 γ_c 更新为 $\gamma_c + n_c$ 。这种先验与后验属于同一分布族的关系称为**共轭** (conjugacy)；“先验参数加计数”来自相乘时指数相加，不是额外规定的平滑技巧。狄利克雷分布的均值是各参数除以参数总和，故后验均值为

$$\tilde{\pi}_c = \frac{n_c + \gamma_c}{n + \sum_{r=1}^C \gamma_r}.$$

先验均值为 $\gamma_c / \sum_r \gamma_r$ ，参数总和决定这些伪计数相对于观测计数的权重。这里“类别先验 π_c ”是样本生成模型的一部分，“参数先验”则表达估计

π 前的不确定性, 两者不是同一个概率。

连续特征可采用**高斯朴素贝叶斯** (Gaussian naive Bayes), 即 $x_j | y = c \sim \mathcal{N}(\mu_{j,c}, \sigma_{j,c}^2)$, 其中 $\sigma_{j,c}^2 > 0$ 。当 $n_c > 0$ 且该特征的类内平方偏差和为正时, 均值和方差的 MLE 为

$$\begin{aligned}\hat{\mu}_{j,c} &= \frac{1}{n_c} \sum_{i: y_i=c} x_{i,j}, \\ \hat{\sigma}_{j,c}^2 &= \frac{1}{n_c} \sum_{i: y_i=c} (x_{i,j} - \hat{\mu}_{j,c})^2.\end{aligned}\quad (3.94)$$

方差分母为 n_c , 不是无偏样本方差所用的 $n_c - 1$ 。在上述条件下, 预测时将这些量代入一维高斯密度后相乘。若某类某特征恒定为 a , 固定 $\mu_{j,c} = a$ 后, 对数似然为 $-n_c \log(2\pi\sigma_{j,c}^2)/2$, 随正方差趋于零而无界增大。因此, 此时正方差参数域内没有有限 MLE; 式(3.94)给出的零值只是样本散度, 不能代入普通高斯密度。设定有明确尺度的方差下限或加入先验后, 得到的是相应的受约束或正则化估计; 给密度任意“加一”不是离散概率的平滑对应物。

只关心某个词是否出现时, 可用**伯努利朴素贝叶斯** (Bernoulli naive Bayes)。输入 $x_{i,j} \in \{0, 1\}$, 令 $n_{j,c} = \sum_{i: y_i=c} x_{i,j}$, 则

$$\begin{aligned}q_c(\mathbf{x}) &= \prod_{j=1}^d \theta_{j,c}^{x_j} (1 - \theta_{j,c})^{1-x_j}, \\ \hat{\theta}_{j,c} &= \frac{n_{j,c}}{n_c}.\end{aligned}\quad (3.95)$$

未出现的词同样提供证据, 不能只保留 $x_j = 1$ 的项; 这里的 MLE 要求 $n_c > 0$ 。为平滑这个二值事件, 可使用**贝塔分布** (Beta distribution) 作为 $\theta_{j,c}$ 的先验。它是二元概率向量 $(\theta_{j,c}, 1 - \theta_{j,c})$ 上的狄利克雷分布, 以 $0 < \theta_{j,c} < 1$ 为密度定义域, 两个正参数 α_1, α_0 分别对应出现与未出现。先验密度正比于 $\theta_{j,c}^{\alpha_1-1} (1 - \theta_{j,c})^{\alpha_0-1}$; 乘以似然后, 两项指数分别增加 $n_{j,c}$ 和 $n_c - n_{j,c}$, 所以

$$\theta_{j,c} | D_n \sim \text{Beta}(\alpha_1 + n_{j,c}, \alpha_0 + n_c - n_{j,c}).$$

其后验均值为 $(n_{j,c} + \alpha_1)/(n_c + \alpha_1 + \alpha_0)$; 对称情形 $\alpha_1 = \alpha_0 = \alpha$ 的分母是 $n_c + 2\alpha$ 。这同时平滑了出现和未出现两种事件。

若重复出现的次数也有意义, 应使用**多项式朴素贝叶斯** (multinomial naive Bayes)。设固定词表有 d 个词项, $\mathbf{x}_i \in \mathbb{N}_0^d$ 记录一篇文档的词项计数, $m_i = \sum_j x_{i,j}$ 是该文档的总词元数。给定类别和 m_i , 假设每个词元位置独立地按 $\theta_c = (\theta_{1,c}, \dots, \theta_{d,c})^\top$ 抽取词项, 其中 $\sum_j \theta_{j,c} = 1$ 。忽略顺序后, 计

数向量服从

$$\mathbb{P}(\mathbf{x}_i | y_i = c, m_i) = \frac{m_i!}{\prod_{j=1}^d x_{i,j}!} \prod_{j=1}^d \theta_{j,c}^{x_{i,j}}. \quad (3.96)$$

因为计数总和已固定，各维计数并不独立。将它写成每维整数取值的独立类别分布，会改变模型和分母。McCallum 与 Nigam 专门比较了伯努利和多项式这两种文档事件模型，明确区分“词是否出现”与“词出现多少次”⁶⁴。

标准文档分类通常进一步假设长度分布与类别无关，因而 $\mathbb{P}(m_i | y_i = c)$ 在类别比较中约掉，此时给定长度后的类先验仍为 π_c 。若长度本身携带类别信息，则应保留并估计该项，使长度也参与后验计算。

令 $t_{j,c} = \sum_{i: y_i=c} x_{i,j}$ 为第 c 类中词项 j 的总出现次数， $t_c = \sum_j t_{j,c}$ 为该类的总词元数。去掉与参数无关的组合系数后，类内对数似然为 $\sum_j t_{j,c} \log \theta_{j,c}$ 。当 $t_c > 0$ 时，在 $\sum_j \theta_{j,c} = 1$ 约束下求极值，正计数坐标上的拉格朗日方程给出 $t_{j,c}/\theta_{j,c}$ 为同一常数，零计数坐标取零；求和确定常数为 t_c ，从而得到频率 MLE。

若对 θ_c 使用 $\text{Dirichlet}(\alpha_1, \dots, \alpha_d)$ 先验，其中 $\alpha_j > 0$ ，同样的共轭更新把各坐标的幂次从 $\alpha_j - 1$ 变为 $\alpha_j + t_{j,c} - 1$ ，得到

$$\theta_c | D_n \sim \text{Dirichlet}(\alpha_1 + t_{1,c}, \dots, \alpha_d + t_{d,c}).$$

把更新后的参数归一化即可得到后验均值。两种估计分别为

$$\hat{\theta}_{j,c} = \frac{t_{j,c}}{t_c}, \quad \tilde{\theta}_{j,c} = \frac{t_{j,c} + \alpha_j}{t_c + \sum_{r=1}^d \alpha_r}. \quad (3.97)$$

前式要求 $t_c > 0$ ；后式也给出下一词元的后验预测概率，因为给定参数时该概率为 $\theta_{j,c}$ ，对参数后验积分便得到其后验均值。这种均值估计通常既不同于 MLE，也不同于式(2.36)定义的 MAP。对称 $\alpha_j = 1$ 给出**拉普拉斯平滑** (Laplace smoothing)，相当于每个词项加入一个伪计数； $\alpha_j = 1/2$ 对应多项式参数的 Jeffreys 先验。对伯努利参数，其对应物是 $\text{Beta}(1/2, 1/2)$ ，不应把这些常数不加区分地推广到高斯方差。以平滑估计代入式(3.96)得到的是常用的点估计分类器，不等于积分消去参数后的整篇文档预测分布。

在长度与类别无关的约定下，文档预测只需计算 $\log \tilde{\pi}_c + \sum_j x_j \log \tilde{\theta}_{j,c}$ 。算法3.5给出完整的统计与预测流程，训练和预测使用相同的词表，并明确处理平滑与得分平局。

算法 3.5 带平滑的多项式朴素贝叶斯

输入： 非空训练集 D_n ，固定词表大小 d 与类别数 C ；
词项伪计数 $\alpha > 0$ ，类别伪计数 $\gamma > 0$

⁶⁴ A. McCallum, K. Nigam, *A Comparison of Event Models for Naive Bayes Text Classification In Learning for Text Categorization: Papers from the 1998 Workshop*, 1998, pp. 41–48

输出： 类先验 $\tilde{\pi}$ 、词项概率 $\tilde{\Theta}$ 及预测规则

```

1: 检查所有输入为有限非负整数计数, 标签属于  $\{1, \dots, C\}$ 
2: 将  $n_c$ 、 $t_c$  与  $t_{j,c}$  全部初始化为零
3: for  $i = 1, \dots, n$  do
4:   令  $c = y_i$ , 并更新  $n_c \leftarrow n_c + 1$ 
5:   for 满足  $x_{i,j} > 0$  的词项  $j$  do
6:      $t_{j,c} \leftarrow t_{j,c} + x_{i,j}$ 
7:      $t_c \leftarrow t_c + x_{i,j}$ 
8:   end for
9: end for
10: for  $c = 1, \dots, C$  do
11:    $\tilde{\pi}_c \leftarrow (n_c + \gamma)/(n + C\gamma)$ 
12:   对所有  $j$ , 令  $\tilde{\theta}_{j,c} \leftarrow (t_{j,c} + \alpha)/(t_c + d\alpha)$ 
13: end for
14: 对新计数向量  $\mathbf{x}$ , 按相同词表与输入检查计算
    
$$s_c = \log \tilde{\pi}_c + \sum_{j: x_j > 0} x_j \log \tilde{\theta}_{j,c}$$

15: 返回  $s_c$  最大的类别; 平局时返回索引最小的类别

```

假设词表只有三个词项, 两类累计计数分别为 $(3, 1, 0)$ 和 $(0, 1, 3)$, 类先验均为 $1/2$ 。取 $\alpha = 1$, 平滑后的词项概率分别为 $(4, 2, 1)/7$ 和 $(1, 2, 4)/7$ 。对新文档 $\mathbf{x} = (1, 0, 1)^\top$, 两类乘积相同, 判决平局; 对 $\mathbf{x} = (2, 0, 1)^\top$, 两类得分之差为 $\log 4$, 于是选择第 1 类。这个教学例子显示了重复计数怎样改变证据, 而零计数词项经平滑后不会把整类概率直接清零。

3.4.2.3 理论分析

收敛性分析 NB 的计数估计有闭式表达式, 这里的收敛问题不是迭代优化何时停止, 而是样本增加后估计量趋向什么。固定特征维数、类别数和有限取值集合, 在独立同分布抽样且各类先验为正时, 强大数定律保证经验类频率和类内相对频率几乎必然收敛到对应的真实概率。固定伪计数相对于不断增长的类内样本数趋于零, 因此不改变这一极限。

单维条件概率估计一致, 并不要求同一样本的多维特征条件独立; 但把这些概率相乘后能否还原真实联合分布, 需要额外的模型假设。高斯 NB 若要一致地估计类条件密度, 还要求高斯族正确、方差非退化并使用一致估计。多项式 NB 则要求词元生成与长度处理假设正确, 训练文档的抽样及总计数满足相应大数定律。有限离散情形的频率收敛证明包含在下面的风险一致性证明中。

泛化分析 估计量收敛后, 还需回答由这些估计构造的分类器能否接近贝叶斯风险。下面先在模型正确的有限离散情形下给出完整证明, 再考察条件独立不成立时, 哪些依赖会改变决策。这个结论描述样本数趋于无穷时的风险, 不是有限样本的误差上界, 也无需排除后验平局。

定理 3.12 有限离散特征下 NB 的风险一致性 设 d, C 固定, 每维特征的取值集合有限, 训练样本独立同分布, 且每类先验 $\pi_c > 0$ 。若真实分布满足给定类别后的特征条件独立, 使用经验类频率与类内相对频率估计概率, 或加入固定的正伪计数, 则所得 NB 分类器 $\hat{h}_n$ 满足

$$R(\hat{h}_n) \longrightarrow R^* \quad \text{几乎必然.}$$

这里 $R(h) = \mathbb{P}(h(\mathbf{X}) \neq Y)$ 针对独立的新样本计算, R^* 为贝叶斯风险; 几乎必然收敛针对无限训练样本序列。早期若 $n_c = 0$, 可任意指定该类的条件分布; 若某输入的全部类别得分为零, 也可任意指定该处的预测。

证明. 对取值 v 及 $n_c > 0$ 的类别, 类内估计为

$$\hat{p}_{j,c}(v) = \frac{\sum_{i=1}^n \mathbb{1}\{x_{i,j} = v, y_i = c\}}{n_c}.$$

由强大数定律, $n_c/n \rightarrow \pi_c > 0$, 故空类别事件几乎必然最终不再出现。分子除以 n 收敛到 $\mathbb{P}(X_j = v, Y = c)$, 因此 $\hat{p}_{j,c}(v) \rightarrow p_{j,c}(v)$ 几乎必然。固定伪计数相对于 n_c 趋于零, 不改变极限。有限多个估计可同时收敛; 对每个 $\mathbb{P}(\mathbf{X} = \mathbf{x}) > 0$ 的输入, 归一化分母最终为正, 早期任意约定不影响极限。乘积与归一化于是给出

$$\hat{\eta}_{n,c}(\mathbf{x}) \longrightarrow \eta_c(\mathbf{x}) = \mathbb{P}(Y = c \mid \mathbf{X} = \mathbf{x}).$$

令 c^* 最大化真实后验, $\hat{c}$ 最大化估计后验。因为 $\hat{\eta}_{n,\hat{c}} \geq \hat{\eta}_{n,c^*}$, 插入这两个估计值得到

$$0 \leq \eta_{c^*}(\mathbf{x}) - \eta_{\hat{c}}(\mathbf{x}) \leq 2 \max_c |\hat{\eta}_{n,c}(\mathbf{x}) - \eta_c(\mathbf{x})|.$$

左侧就是该输入处的超额分类风险。对有限个输入按真实概率加权求和, 右侧趋于零, 故整体风险趋于 R^* 。 ■

后验平局时, 最大化类别可能随 n 变化, 但选择不同的最优类别并不增加风险。因此, 风险一致性不等于决策最终处处固定, 更不能由“依概率收敛”直接推出无条件的决策几乎必然一致。若模型失配, 估计可能稳定地收敛到不同于真实联合分布的乘积分布; 增加样本能减小估计误差, 却不会自动消除这种模型偏差。

真实数据中的词语、测量量和相邻像素常有依赖, 但违反独立性并不直接决定分类误差。Domingos 与 Pazzani 在 1997 年的研究区分了概率估计误差与零一分类损失, 报告了含依赖数据上的经验结果, 并在特定条件下

分析了合取、析取概念等情形的最优性。分类只要求最高得分类别正确，因此概率估计失真与分类仍然准确可以同时发生⁶⁵。

为拆开这些层次，暂取二分类 $c \in \{0, 1\}$ ，并使用真实类先验与真实单维条件分布构造总体 NB，不含有限样本估计误差。在下列分母均为正的输入处，定义

$$\begin{aligned} r(\mathbf{x}) &= \frac{\pi_1 p(\mathbf{x} | y = 1)}{\pi_0 p(\mathbf{x} | y = 0)}, \\ r_{\text{NB}}(\mathbf{x}) &= \frac{\pi_1 \prod_j p(x_j | y = 1)}{\pi_0 \prod_j p(x_j | y = 0)}. \end{aligned} \quad (3.98)$$

若平局都归第 1 类，则两个分类器在该输入上的决策相同，当且仅当 $r \geq 1$ 与 $r_{\text{NB}} \geq 1$ 同真同假。理由只是：用正的第 0 类联合得分除两边，不改变类别得分的大小关系。这是从判决规则直接得到的等价关系，不是对 NB 有效范围的独立保证；其中 r 还是未知真分布的量。

要解释依赖何时不会改变比值，可以进一步定义

$$\begin{aligned} a_c(\mathbf{x}) &= \frac{p(\mathbf{x} | y = c)}{\prod_{j=1}^d p(x_j | y = c)}, \\ r(\mathbf{x}) &= r_{\text{NB}}(\mathbf{x}) \frac{a_1(\mathbf{x})}{a_0(\mathbf{x})}. \end{aligned} \quad (3.99)$$

a_c 衡量真实联合分布相对于乘积分布的修正。条件独立使 $a_c = 1$ ；更弱的充分条件是 $a_1 = a_0 > 0$ ，此时即使两类内部都有依赖，其修正在类别比值中也完全相消。由概率链式法则还可写成

$$a_c(\mathbf{x}) = \prod_{j=1}^d \frac{p(x_j | x_1, \dots, x_{j-1}, y = c)}{p(x_j | y = c)}.$$

各因子不必分别为一，不同位置的修正也可在整体乘积中抵消。所需比较的是两类中这些概率修正的比值，而不只是通常的相关系数。Zhang 在 2004 年以局部依赖比和全局依赖分布因子展开了这一思路⁶⁶。

完全相消仍只是充分条件。若 $r_{\text{NB}} \neq 1$ ，且

$$|\log a_1(\mathbf{x}) - \log a_0(\mathbf{x})| < |\log r_{\text{NB}}(\mathbf{x})|,$$

则修正不足以改变对数比的正负，决策仍然相同。反之，依赖影响在两类中不均衡时就可能越过边界。例如把一个有信息的二值特征原样复制一次，在等类先验下，NB 把原似然比平方：原比值为 4 时，真实后验为 4/5，NB 却报 16/17，分类未变而置信度偏高。非等先验下，特征证据被重复计算还可能改变类别，这说明同一个依赖错误对概率与决策的影响可以不同。

⁶⁵ P. Domingos, M. Pazzani, *On the Optimality of the Simple Bayesian Classifier under Zero-One Loss* In Machine Learning, 1997, vol. 29, no. 2-3, pp. 103-130

⁶⁶ H. Zhang, *The Optimality of Naive Bayes* In Proceedings of the Seventeenth International Florida Artificial Intelligence Research Society Conference, 2004, pp. 562-567

3.4.2.4 小结

NB 的计算优势来自统计量可累积：稠密输入的训练统计约为 $O(nd)$ ，存储为 $O(Cd)$ ，单样本预测为 $O(Cd)$ ，这些量级以每维分布的参数个数有界为前提。以 $\mathbf{X} \in \mathbb{R}^{n \times d}$ 记训练输入矩阵，多项式模型可按非零计数累积，训练约为 $O(n + \text{nnz}(\mathbf{X}) + Cd)$ ，预测约为 $O(C(1 + \text{nnz}(\mathbf{x})))$ 。这里 nnz 表示非零元素数；“扫描一次”不意味着与样本数、特征数和类别数都无关。

它适合建立文档、垃圾邮件和情感分类的低成本基线，也容易增量更新。Graham 在 2002 年 8 月的《A Plan for Spam》中介绍了基于词项统计的邮件过滤实践；该方法还加入词项筛选与经验修正，与本节的标准多项式模型有所不同⁶⁷。

使用 NB 时要分别检查输入的事件模型、特征依赖和概率校准。相关性可能造成证据重复计算，却不必然破坏分类；连续特征还可能因所选单维分布失配而出错。若业务需要可靠概率，应另用留出数据评估和校准，而不只报告准确率。

⁶⁷ P. Graham, *A Plan for Spam*, Aug. 2002, URL: <https://paulgraham.com/spam.html>

3.4.3 高斯判别分析 (GDA)

高斯 NB 只保存每维的均值与方差，相当于把类内协方差矩阵的非对角元素设为零。若分类信息恰好体现在多个连续特征的共同变化中，就需要估计这些关系。**高斯判别分析** (Gaussian discriminant analysis, GDA) 用每类的多元高斯分布描述输入，允许保留类内协方差；增加的表达能力也意味着需要估计更多参数。

第 4.6.1 节的高斯混合模型同样估计高斯成分及其权重，但成分归属是潜变量，通常用**期望最大化** (expectation-maximization, EM) 交替计算成分归属的后验概率并更新分布参数；两步计算的分类实例见第 3.6.4 节。GDA 中的类别标签已经观测，可以直接按类分组估计。两者共享高斯密度结构，却分别服务于预设类别预测和无标签分组。

从类间分离程度转向概率决策，关注的问题也从“怎样区分类别”扩展为“怎样权衡误判”。Anderson 在 1951 年的多元分类研究中，以误分类代价为依据讨论分类规则，并在正态总体下给出判别函数。这为理解 GDA 提供了一条历史线索：分布模型负责描述输入来自各类的可能性，决策规则再据此比较误判代价，而不只是寻找一个投影方向⁶⁸。

⁶⁸ T. W. Anderson, *Classification by Multivariate Analysis In Psychometrika*, 1951, vol. 16, no. 1, pp. 31–50

3.4.3.1 模型结构

本节用 GDA 统称各类具有高斯条件分布的判别模型，并分别讨论共享协方差与类特有协方差。对第 c 类，参数是 π_c 、 $\mu_c \in \mathbb{R}^d$ 及对称正定的

$\Sigma_c \in \mathbb{R}^{d \times d}$:

$$p(\mathbf{x} | y = c) = \frac{\exp[-\Delta_c(\mathbf{x})/2]}{(2\pi)^{d/2} |\Sigma_c|^{1/2}}, \quad (3.100)$$

$$\Delta_c(\mathbf{x}) = (\mathbf{x} - \boldsymbol{\mu}_c)^\top \Sigma_c^{-1} (\mathbf{x} - \boldsymbol{\mu}_c).$$

这里的二次型 Δ_c 按类内变化尺度衡量输入偏离均值的程度；行列式项则补偿分布体积，不能在不同协方差的类别比较中丢掉。贝叶斯后验仍为 $\pi_c p(\mathbf{x} | y = c) / \sum_r \pi_r p(\mathbf{x} | y = r)$ 。

取对数并删除所有类别共有的 $-d \log(2\pi)/2$ ，得到判别得分

$$g_c(\mathbf{x}) = \log \pi_c - \frac{1}{2} \log |\Sigma_c| - \frac{1}{2} \Delta_c(\mathbf{x}). \quad (3.101)$$

预测选择最大 g_c 。这一模型不要求各特征独立，但要求整类分布可由单个多元高斯刻画；“保留完整协方差”只是保留全部二阶关系，不是能表达任意非线性依赖或多峰结构。

3.4.3.2 参数学习

有标签时，各类样本的归属已知，联合对数似然可按类别分开优化。当每类都有样本且类内散度矩阵正定时，MLE 为

$$\begin{aligned} \hat{\pi}_c &= \frac{n_c}{n}, \\ \hat{\boldsymbol{\mu}}_c &= \frac{1}{n_c} \sum_{i: y_i = c} \mathbf{x}_i, \\ \hat{\Sigma}_c &= \frac{1}{n_c} \sum_{i: y_i = c} (\mathbf{x}_i - \hat{\boldsymbol{\mu}}_c)(\mathbf{x}_i - \hat{\boldsymbol{\mu}}_c)^\top. \end{aligned} \quad (3.102)$$

均值来自使类内平方偏差最小的驻点，协方差来自似然中的对数行列式与二次型之间的平衡。和高斯 NB 一样，这里使用 MLE 分母 n_c ；若改用 $n_c - 1$ ，得到的是无偏协方差估计。若类内散度奇异，沿未被样本覆盖的方向收缩方差可使似然不断增大，在协方差正定的参数域内没有有限 MLE；此时上式的奇异矩阵只能作为样本散度统计，不能当成合法的普通高斯协方差。

共享协方差特例的完整推导已经放在第3.1.1节。简要地说，约束 $\Sigma_c = \Sigma$ 后，合并类内散度给出式 (3.7) 的 MLE；展开高斯得分时，各类共有的 $\mathbf{x}^\top \Sigma^{-1} \mathbf{x}$ 相消，得到式 (3.2) 的线性得分。两类得分相等因而给出超平面。若协方差随类变化，二次项一般不能约掉，得到 QDA 及通常为二次曲面的两类边界。共享与否改变的并非贝叶斯规则，而是允许分布族及由此得到的得分形式⁶⁹。

图3.7在同一个二维教学例子中比较两种协方差设定。两图都取 $\pi_1 = \pi_2 = 1/2$ 、 $\boldsymbol{\mu}_1 = (-1, 0)^\top$ 、 $\boldsymbol{\mu}_2 = (1, 0)^\top$ ，坐标为无量纲特征。左图共享 $\Sigma_1 = \Sigma_2 = \mathbf{I}_2$ ；右图只将第2类改为 $\Sigma_2 = \text{diag}(1, 4)$ 。代入式(3.101)，得分

⁶⁹ C. M. Bishop, *Pattern Recognition and Machine Learning*, Springer, 2006, 1st ed.

差分别为

$$\begin{aligned} g_2 - g_1 &= 2x_1 && \text{(共享协方差)}, \\ g_2 - g_1 &= 2x_1 + \frac{3}{8}x_2^2 - \log 2 && \text{(类特有协方差)}. \end{aligned} \quad (3.103)$$

令得分差为零, 得到直线 $x_1 = 0$ 和抛物线 $x_1 = \frac{1}{2} \log 2 - \frac{3}{16}x_2^2$ 。在两种设定中, 边界右侧的 g_2 都更大, 预测第 2 类。右图中, 第 2 类沿 x_2 方向更分散: 在 $x_2 = 0$ 附近, 行列式项降低了它的密度峰值, 边界向右移到 $x_1 \approx 0.347$; 随着 $|x_2|$ 增大, 第 2 类较慢衰减的密度又使其预测区域向左延伸。只看均值之间的距离, 会漏掉方差尺度和密度归一化对判决的共同影响。




图 3.7 两图均取 $\pi_1 = \pi_2 = 1/2$ 、 $\mu_1 = (-1, 0)^T$ 、 $\mu_2 = (1, 0)^T$ 和 $\Sigma_1 = I_2$, 仅第 2 类协方差变化。蓝色圆点和黄色方点为均值, 蓝色实线与黄色虚线分别为 $\Delta_1 = 1$ 和 $\Delta_2 = 1$ 的等密度轮廓; 不同类的这些轮廓不保证密度值相同。红色粗线按 $g_1 = g_2$ 的解析式绘制, 底部公式分别给出 LDA 的线性边界与 QDA 的二次边界。参数均为教学构造, 不是采样或拟合结果。

对二分类, 把式 (3.2) 中的两类得分相减并归一化, 就得到 Logistic 形式的后验。因此, 共享高斯假设蕴含线性对数几率, 反过来却不成立; 许多非高斯输入分布也能有 Logistic 形式的条件概率。即便两条路线的后验形式相同, 用联合似然估计均值和协方差, 与直接最大化条件似然, 也通常得到不同的有限样本参数。

完整协方差每类需要 $d(d+1)/2$ 个自由参数。类内散布矩阵的秩至多为 $n_c - 1$, 因而 $n_c \leq d$ 时必然奇异, 不能直接代入普通高斯密度; $n_c > d$ 也不保证估计准确或条件良好。共享估计的秩至多为 $n - C$ 。在维数较大或类别样本少时, 可以共享、取对角, 或采用

$$\tilde{\Sigma}_c = (1 - \rho)\hat{\Sigma}_c + \rho\tau I_d, \quad 0 < \rho \leq 1, \quad \tau > 0$$

这样的收缩估计。 τ 提供方差尺度, ρ 控制偏离样本协方差的程度; 这是

改变估计准则，不再是未经约束的 MLE。

稠密完整协方差的统计成本约为 $O(nd^2)$ ，各类矩阵分解约为 $O(Cd^3)$ ，存储为 $O(Cd^2)$ ，QDA 单样本得分约为 $O(Cd^2)$ 。LDA 只需分解一份协方差，并可预先算出线性权重，使单样本预测降到 $O(Cd)$ 。实现时可用 Cholesky 分解求解二次型与对数行列式，无须显式构造逆矩阵。

3.4.3.3 小结

GDA 用同一套生成式模型连接高斯 NB、LDA 与 QDA：对角协方差忽略类内相关，共享协方差降低估计负担，类特有完整协方差则允许更灵活的边界。三者的选择要结合每类样本量、维数和类内结构，而不是只看总样本数。

偏离高斯假设会使密度模型失配，但不意味着分类性能必然崩塌；只要相关区域的类别得分排序仍然合理，分类仍可能有效。多峰结构、异常值和病态协方差则是需要特别检查的情形。低维连续数据可把共享或正则化 GDA 作为基线，同时与判别式模型比较错误率和概率质量，不能仅凭正态性检验决定胜负。

3.4.4 模型对比与总结

本小节先比较 Logistic 回归、朴素贝叶斯与 GDA，再介绍补集统计和放宽条件独立性的代表性扩展。这几种模型并不能沿“假设越来越强”排成一条直线。Logistic 回归限制后验的对数几率形式，却不限制输入边缘分布；NB 限制给定类别后的依赖结构，还要选择单维或词元的事件模型；GDA 限制整体分布为高斯，但可保留 NB 忽略的协方差。只有指定具体模型族，例如共享协方差 GDA 与线性 Logistic 回归，才能准确讨论假设的包含关系。

表3.3汇总相同监督分类任务下的主要取舍。参数量按每维分布参数有界计算，GDA 的共享与类特有协方差分别列明，避免把两者的代价混在一起。

生成式与判别式方法的样本效率比较，还必须分清“较快接近自己的极限误差”与“达到同一个目标误差”。Ng 和 Jordan 在 NIPS 2001 会议、2002 年出版的论文中，重点比较离散 NB 以及共享对角方差的连续 NB，与相应的 Logistic 回归/线性分类方法。他们分析并观察到两种可能的学习阶段：NB 较快接近自身的极限误差，而判别式方法在数据更多时可能达到更低的误差。结论取决于所比较的模型与分布条件，一般完整协方差 GDA 不在这一结论的直接适用范围内⁷⁰。

其分析中，一定概率或方差下界保证参数估计受控，还需要关于决策边界附近概率质量的条件，才能把参数误差转成分类风险误差。文中的一些

⁷⁰ A. Y. Ng, M. I. Jordan, *On Discriminative vs. Generative Classifiers: A Comparison of Logistic Regression and Naive Bayes* In *Advances in Neural Information Processing Systems 14*, 2001, pp. 841–848

模型	建模与估计	主要取舍
Logistic 回归 / Softmax 回归	直接拟合条件概率; $O(Cd)$ 个参数, 迭代优化	不拟合输入分布; 需检查特征表示、分离与正则化
NB	由先验和简化类条件模型形成后验; 通常 $O(Cd)$ 个参数	计数或矩估计易累积; 依赖和事件模型失配会引入偏差
共享 GDA (LDA)	高斯类条件分布, 共享协方差; $O(d^2 + Cd)$ 个参数	用共同协方差降低估计波动; 只得到线性边界
类特有 GDA (QDA)	各类独立估计协方差; $O(Cd^2)$ 个参数	边界更灵活; 对每类样本量和协方差条件更敏感

表 3.3 概率分类模型的建模对象与估计代价。所有概率输出都需单独检查校准, 参数量不直接等于达到指定精度所需的样本量。

形式化判别结论针对在线性分类器中最小化零一风险, 而不能未经额外论证就替换为交叉熵极小化。由此得到的模型选择原则是: 比较学习曲线、极限偏差和实际目标损失, 而不是从“生成式”三个字推出统一的速度优势。

对文本数据, 除了增加训练样本, 还可以调整参数的统计来源。**补集朴素贝叶斯** (complement naive Bayes, CNB) 用不属于第 c 类的文档构造补集分布, 再寻找与该补集不匹配的输入。Rennie 等在 2003 年提出这一方法, 针对类别不平衡时的权重估计偏差, 并结合其他修正研究文本分类效果⁷¹。

沿用多项式计数, 令 $t_{j,\bar{c}} = \sum_{i: y_i \neq c} x_{i,j}$ 、 $t_{\bar{c}} = \sum_j t_{j,\bar{c}}$ 。先定义补集词项参数及其对数权重:

$$\begin{aligned}\tilde{\theta}_{j,\bar{c}} &= \frac{t_{j,\bar{c}} + \alpha_j}{t_{\bar{c}} + \sum_{r=1}^d \alpha_r}, \\ w_{j,c} &= \log \tilde{\theta}_{j,\bar{c}}, \\ s_c^{\text{CNB}}(\mathbf{x}) &= \log \pi_c - \sum_{j=1}^d x_j w_{j,c}.\end{aligned}\quad (3.104)$$

Rennie 等给出的 CNB 规则选择最大 s_c^{CNB} ; 他们同时说明实验中为简化采用均匀类别先验, 此时等价于选择补集对数得分 $\sum_j x_j w_{j,c}$ 最小的类别。负号使“不像补集”转化为支持第 c 类的证据: $\tilde{\theta}_{j,\bar{c}}$ 表示补集的词项参数, 与正类 $\mathbb{P}(\mathbf{x} | y = c)$ 中的参数是不同对象。补集可能混合多个类别, 本身也未必是单一多项式分布, 因此 CNB 更适合解释为基于补集统计构造的分类得分, 而不是原 NB 正类后验的替代估计。

同一论文还把权重归一化作为另一项修正, 得到 WCNB:

$$\bar{w}_{j,c} = \frac{w_{j,c}}{\sum_{r=1}^d |w_{r,c}|}, \quad \hat{y}(\mathbf{x}) = \arg \min_c \sum_{j=1}^d x_j \bar{w}_{j,c}.$$

论文完整算法还组合了词频、逆文档频率和文档长度变换, 不能把

⁷¹ J. D. M. Rennie, L. Shih, J. Teevan, D. R. Karger, *Tackling the Poor Assumptions of Naive Bayes Text Classifiers* In Proceedings of the Twentieth International Conference on Machine Learning, 2003, pp. 616–623

式(3.104)、WCNB 或包含全部变换的版本写成唯一的 CNB 形式。

常用库实现也有明确取舍。scikit-learn 的 ComplementNB 在多类情形不使用类别先验, 当前默认 `norm=False`, 即预测时比较未作第二次归一化的 $-\sum_j x_j \log \tilde{\theta}_{j,c}$; 设置 `norm=True` 才启用上述权重归一化⁷²。因此, 默认实现既不同于带非均匀 π_c 的式(3.104), 也不同于原论文包含权重归一化的完整算法。补集计数可用全局计数减去类内计数获得, 不必逐类重扫全部数据。CNB 在某些不平衡文本任务中是有价值的候选, 但优势取决于类别组成、特征变换、平滑及评价指标; 相对于多项式 NB 的收益和输出概率的校准程度都需要单独验证。

另一种改进直接放宽依赖结构。**平均单依赖估计器** (averaged one-dependence estimators, AODE) 不是选定唯一父特征, 而是对多个以不同特征为共同父节点的模型作平均。Webb、Boughton 与 Wang 在 2005 年的论文中系统研究了这种方法, 目的是在保留可累积统计量的同时, 利用 NB 未表示的部分特征依赖⁷³。

对离散特征, 设 $S(\mathbf{x})$ 包含那些在训练集中取值 x_s 出现次数达到阈值 m_0 的候选父特征索引。对每个 $s \in S(\mathbf{x})$, 假设其余特征在同时给定类别 $Y = c$ 和父特征 $X_s = x_s$ 后条件独立。平均的联合得分为

$$A_c(\mathbf{x}) = \frac{1}{|S(\mathbf{x})|} \sum_{s \in S(\mathbf{x})} \hat{\mathbb{P}}(Y = c, X_s = x_s) \times \prod_{j \neq s} \hat{\mathbb{P}}(X_j = x_j \mid Y = c, X_s = x_s). \quad (3.105)$$

分类比较 A_c , 需要后验估计时再对 c 归一化。这里平均的是各父特征模型的联合得分, 不是分别归一化后的后验, 也不是忽略类别后只条件于 x_s 的乘积。概率表可由类、父特征与子特征的联合计数加平滑得到; 若 $S(\mathbf{x})$ 为空, 则回退到 NB。筛选父特征取值的频数阈值用于避免条件样本过少, 不代表依赖一定已被准确估计。

若每维最多有 v 个离散取值, 稠密计数表的存储约为 $O(Cd^2v^2)$ 。逐样本累积特征对的训练扫描为 $O(nd^2)$, 另有计数表初始化与处理成本; 单样本预测最坏为 $O(Cd^2)$ 。因此 AODE 可以一次扫描并增量学习, 但不能据此称它的特征复杂度为线性。对词表极大的稀疏文本, 这些成对统计也可能成为主要负担。

回到本节开头的问题, 概率建模提供了把特征证据、类别决策和误判代价联系起来的语言, 但概率的可解释形式不等于数值已经可靠。实际选择应同时考察输入表示、每类样本量、依赖结构、训练与预测成本, 以及目标更重视错误率还是概率质量。Logistic、NB、GDA 与这些变种提供了不同的约束与估计方法, 而不是对所有概率分类器的穷尽分类; 最终仍应在与部署分布相符的留出数据上比较它们。

⁷² scikit-learn developers, *ComplementNB API Documentation, Version 1.9.1*, 2026, URL: https://scikit-learn.org/stable/modules/generated/sklearn.naive_bayes.ComplementNB.html (visited on 10/03/2026)

⁷³ G. I. Webb, J. R. Boughton, Z. Wang, *Not So Naive Bayes: Aggregating One-Dependence Estimators* In Machine Learning, 2005, vol. 58, no. 1, pp. 5–24

3.5 基于集成的分类

第1.2.5节给出成员组合的基本动机，第6章系统讨论 Bagging、Boosting、Stacking 及成员简化。本节只比较组合后交付什么分类信息，以及分类损失、阈值和概率校准怎样影响使用。回归树也可以作为分类集成的成员：GBDT 用树拟合类别得分的修正，整体模型再给出类别决策；成员本身的输出类型不决定整体任务。

方法	分类输出	任务中的条件与代价
Bagging	硬标签投票，或平均成员得分／概率后决策	概率平均不自动校准；预测成本随所用成员增加
随机森林	树投票或叶类别比例平均	树深、特征抽样与树数需选择；袋外诊断不替代测试
AdaBoost	对弱分类器加权投票或输出累计得分	加权分类问题上的成员表现与噪声影响轮次选择
GBDT	累加类别得分，再按阈值或 Softmax 决策	分类损失决定修正；树深、学习率与早停共同影响结果
Stacking	元学习器组合标签、得分或概率	组合层用留出或折外基预测训练；校准仍需独立检验

表 3.4 集成方法的分类输出与使用条件。共同训练机制已在简介中说明；此处按相同分类目标比较，不把成员数量视为性能保证。

第二卷“基础、理论和可信性”的“二分类学习的可学习性”章“集成学习”节的投票、弱学习与提升风险解释组合可能带来什么收益。实际评价仍须按表3.7区分标签错误、排序、概率质量与误判代价，并计入训练和预测所需的全部成员；单个成员的概率或解释性质不能直接当作整体性质。

3.6 半监督分类

前面介绍的分类器依靠带标签的样本选择决策边界，但能够收集到的输入往往多于能够完成标注的样本。例如，积累一批待分类文档相对容易，逐篇判断主题却需要人工阅读。如果只使用已经标注的少量文档，其余文档所反映的词语共现和主题聚集结构就没有参与学习。**半监督分类**（semi-supervised classification）试图利用这部分信息：由真实标签确定类别含义，再借助未标注输入约束预测规则。

本节把全部 n 个样本的索引分成不相交的有标签集合 L 与无标签集合 U ，满足 $L \cup U = \{1, \dots, n\}$ 。每个输入为 $\mathbf{x}_i \in \mathbb{R}^d$ ，只有 $i \in L$ 时可以在训练中使用真实标签 y_i ；除二分类的专门约定外，类别取值为 $\{1, \dots, C\}$ 。这里的“无标签”描述算法可用的信息，不表示样本在真实任务中没有类别。标签稀缺是学习条件，树、概率模型和间隔模型则描述怎样表示或学习分类规则，因而半监督方法可以与前面几节的模型组合使用。

仅仅知道输入分布，还不能唯一确定标签如何分配。同样的两团文档，

既可能对应两个主题,也可能只是写作风格不同而主题相同。因此,未标注数据能否帮助分类,取决于输入结构与类别之间是否存在可利用的联系;即使两类样本来自同一输入分布,也不能据此保证半监督训练有益。分布不匹配、标签采样偏差以及未知类别混入,还会进一步削弱这种联系。Cozman 与 Cohen 对生成式分类器的分析给出了直接的负面结果:当建模假设与真实生成分布不一致时,加入未标注数据可能增大渐近偏差和分类错误⁷⁴。这一结论针对其分析的生成式模型,并不表示任意半监督方法都会因未标注数据而退化。

三种代表方法从不同信息入手回答这一问题。Self-Training 相信经过筛选的模型预测可以补充监督; Label Propagation 要求图上相邻样本的标签倾向于相似; TSVM 则借助未标注样本寻找穿过低密度区域的分界面。这些条件并不互斥,也不是由弱到强的严格等级。接下来分别考察它们怎样使用无标签输入、怎样求解,以及求解成功为什么仍不等于分类一定改善。

3.6.1 Self-Training

已经有一个可用分类器时,最直接的办法是让它从未标注样本中挑选自己较有把握的预测,作为下一轮训练的补充。**自训练**(self-training)就是这样一种外层策略:基分类器负责预测,外层循环负责筛选预测并扩充训练集。用机器自身的输出代替部分教师信号的思想,在 Scudder 于 1965 年研究的自适应模式识别方法中已经出现;现代自训练的筛选、加权和重训方式则可以有许多不同实现⁷⁵。

3.6.1.1 模型结构

自训练不要求一种新的决策边界形式。基分类器仍可采用 Logistic 回归、SVM、决策树或随机森林;新增的部分是怎样管理暂时没有真实标签的样本。为了不混淆真实监督与模型生成的监督,保持原始 L 和 U 不变,用 $A^{(t)} \subseteq U$ 记录第 t 轮已经采纳伪标签的样本索引,用 $R^{(t)} = U \setminus A^{(t)}$ 记录剩余候选池。初始时 $A^{(0)} = \emptyset$,模型只在 L 上训练。

假设基分类器以参数 θ 给出类别概率估计 $p_{\theta}(c | \mathbf{x})$ 。本节讨论一种阈值筛选方式,把最大类别概率作为**置信度**(confidence),即模型对自己当前分类结果的确定程度。对 $j \in R^{(t)}$,计算

$$\begin{aligned}\hat{y}_j^{(t)} &= \arg \max_{1 \leq c \leq C} p_{\theta^{(t)}}(c | \mathbf{x}_j), \\ q_j^{(t)} &= \max_{1 \leq c \leq C} p_{\theta^{(t)}}(c | \mathbf{x}_j), \\ B^{(t)} &= \{j \in R^{(t)} : q_j^{(t)} \geq \tau\}.\end{aligned}\tag{3.106}$$

其中 τ 是预先选择的阈值,通常取 $1/C < \tau < 1$;遇到并列最大值时,本节统一取编号最小的类别。被采纳的预测 $\tilde{y}_j = \hat{y}_j^{(t)}$ 称为**伪标签**(pseudo-label):

⁷⁴ F. G. Cozman, I. Cohen, *Unlabeled Data Can Degrade Classification Performance of Generative Classifiers* In Proceedings of the Fifteenth International Florida Artificial Intelligence Research Society Conference, 2002, pp. 327–331

⁷⁵ H. J. Scudder III, *Probability of Error of Some Adaptive Pattern-Recognition Machines* In IEEE Transactions on Information Theory, 1965, vol. 11, no. 3, pp. 363–371

它是模型提出的临时训练目标，并没有经过真实标注确认。本节的基本版本在采纳后固定该标签；允许重估或撤销伪标签的版本需要另外规定更新规则。

这里的概率输出是筛选接口，不是所有分类器天然具有的能力。SVM 的决策分数表示带符号的间隔，不能直接当成概率与 τ 比较；若要采用概率阈值，应使用独立标注数据拟合并检验相应的概率映射。即便分类器直接输出概率，也需要检查高置信度样本实际有多可靠。在一个教学例子中，二分类预测 (0.96, 0.04) 会通过 $\tau = 0.9$ 的筛选，而 (0.55, 0.45) 不会；这一筛选只说明前者符合模型的接受条件，并没有证明前者的真实类别就是 1。

3.6.1.2 参数学习

每轮采纳伪标签后，基分类器需要重新拟合。以可加权的损失 ℓ 为例，当前训练目标可以写成

$$\begin{aligned} \mathcal{J}_t(\theta) = & \frac{1}{|L|} \sum_{i \in L} \ell(f_{\theta}(\mathbf{x}_i), y_i) \\ & + \frac{\eta}{\max\{1, |A^{(t)}|\}} \sum_{j \in A^{(t)}} \ell(f_{\theta}(\mathbf{x}_j), \tilde{y}_j) \\ & + \beta \Omega(\theta). \end{aligned} \quad (3.107)$$

这里 L 非空， $\eta \geq 0$ 控制伪标签项的相对权重， $\beta \Omega$ 沿用基分类器的正则化方式。空伪标签集的求和取零。分别归一化两类样本，是为了避免仅因伪标签数量增加就让它们压过真实标签；若采用统一样本权重，其相对影响会随集合大小改变。对于树等不直接求解这个目标的分类器，可以使用对应的带权拟合接口，自训练的集合更新逻辑不变。

算法3.6给出固定阈值、固定已采纳伪标签的版本。Fit(A) 表示用真实标签集与索引为 A 的伪标签集完成一次基分类器训练，并返回参数；式 (3.107) 是这种训练的一种具体实现。算法中省略集合的迭代上标，始终让当前参数对应当前已采纳的训练集。

算法 3.6 带最终重训的自训练

输入： 有标签索引 L 、无标签索引 U 及其输入
输入： 阈值 τ 、最大扩充轮数 $T \geq 0$
输出： 分类器 f_{θ} 、已采纳索引 A 和剩余索引 R

```

1:  $A \leftarrow \emptyset$ ,  $R \leftarrow U$ 
2:  $\theta \leftarrow \text{Fit}(A)$ 
3: for  $t = 1, \dots, T$  do
4:   if  $R = \emptyset$  then
5:     break
6:   end if
```

```

7:   用当前模型计算  $R$  中的  $\hat{y}_j$  与  $q_j$ 
8:    $B \leftarrow \{j \in R : q_j \geq \tau\}$ 
9:   if  $B = \emptyset$  then
10:    break
11:  end if
12:  保存  $\tilde{y}_j \leftarrow \hat{y}_j, j \in B$ 
13:   $A \leftarrow A \cup B, R \leftarrow R \setminus B$ 
14:   $\theta \leftarrow \text{Fit}(A)$ 
15: end for
16: return  $f_\theta, A, R$ 

```

把重训放在集合扩充之后有一个直接作用：无论这一轮恰好用完最大轮数，还是把剩余池清空，返回的模型都已经使用了本轮加入的伪标签。若把训练放在循环开头、随后只添加样本就退出，最后一批伪标签实际上不会影响返回模型。预测前检查空池也很必要，空输入未必被基分类器的批量预测接口接受。当 U 为空或 $T = 0$ 时，算法自然返回纯监督模型。

图3.8把算法中的集合变化与模型反馈放在同一条流程中。应注意返回预测步骤的箭头：它传回的是用新增伪标签重训后的模型，而不是一批经过人工确认的标签。真实标签始终固定在 L 中；未通过筛选的样本仍留在 R ，已采纳的样本进入 A ，也不会因此成为真实标注样本。




图 3.8 固定阈值、固定已采纳伪标签的自训练流程，对应算法 3.6。真实标签保持不变，虚线框中的伪标签始终是模型预测。每次采纳后先重训，再用更新后的模型处理剩余候选；空池、无样本通过筛选或达到轮数上限时停止。这个模型反馈回路也可能产生确认偏差：错误预测被当作后续监督，使模型进一步强化原有误判。

阈值并非唯一的筛选手段。每轮可以只采纳通过阈值的前若干个样本，

以控制一次错误扩充的影响；也可以按类别限制数量，避免某个易预测类别占据全部新增监督。这些策略改变的是 $B^{(t)}$ 的构造，不改变先保存标签、再扩充集合、随后重训的顺序。类别配额应参考真实任务中的类别比例，不能为了数量整齐就把不平衡任务强行改成均衡任务。

3.6.1.3 理论分析

收敛性分析 这个基本版本何时停止，可以直接从集合变化判断。每次成功扩充至少从 R 移走一个样本，且样本不会移回，因此成功扩充最多发生 $\min\{T, |U|\}$ 次；若没有样本通过筛选，循环会更早结束。只要每次基分类器训练能够返回，外层循环就会有限终止。这不是对统计最优性的证明，也不代表一系列参数收敛到某个固定目标的全局极小值，因为训练集及其监督信号一直在变化。

自训练与**熵最小化** (entropy minimization) 有共同的倾向：都可能让未标注样本上的预测变得更确定。熵最小化直接惩罚模型预测分布的条件熵，推动概率集中到少数类别。Grandvalet 与 Bengio 讨论了这一准则及其与自训练的联系，但这种联系依赖具体的概率模型和优化设定，不能把所有硬伪标签流程都视为同一个优化问题⁷⁶。

对一个未标注输入 $\mathbf{x}$ ，Shannon 熵与硬伪标签交叉熵分别涉及

$$H_{\theta}(\mathbf{x}) = - \sum_{c=1}^C p_{\theta}(c | \mathbf{x}) \log p_{\theta}(c | \mathbf{x}), \quad (3.108)$$

$$\min_{\tilde{y} \in \{1, \dots, C\}} \{-\log p_{\theta}(\tilde{y} | \mathbf{x})\} = -\log \max_c p_{\theta}(c | \mathbf{x}).$$

前者对所有类别求加权和，后者只取概率最大的一个类别，两者数值和梯度一般不同。例如，预测为 (0.8, 0.2) 时，以自然对数计算的熵约为 0.500，最小硬标签交叉熵约为 0.223。实际自训练还会筛选样本并冻结历史伪标签，因此下一轮甚至不一定仍以当前最大概率类别为目标。

泛化分析 在平滑性与模型容量约束合适时，提升同一聚集区域内的预测确定性，可能促使决策边界远离该区域；但仅在单个输入上降低熵，并不自动约束附近输入的分类。更关键的是，熵只衡量确定程度，不衡量答案是否正确。若初始分类器错误地把一批同主题文档判成另一类，采纳这些预测后再训练，模型可能对原错误更加确信。这种把自身误判重新当作证据的现象称为**确认偏差** (confirmation bias)。Arazo 等在深度图像分类实验中观察到，朴素伪标签训练会拟合错误伪标签，并比较了缓解这一现象的正则化方法⁷⁷。这项证据支持错误可能被反馈回路强化，不构成所有自训练流程必然恶化的普遍定理。

伪标签错误怎样影响真实风险，可以在固定一轮模型后直接推导。令

⁷⁶ Y. Grandvalet, Y. Bengio, *Semi-supervised Learning by Entropy Minimization* In *Advances in Neural Information Processing Systems*, 2004, pp. 529–536

⁷⁷ E. Arazo, D. Ortego, P. Albert, N. E. O'Connor, K. McGuinness, *Pseudo-Labeling and Confirmation Bias in Deep Semi-Supervised Learning* In *2020 International Joint Conference on Neural Networks*, 2020, pp. 1–8

h 为这一轮产生伪标签的分类器, $\mathbf{X}_\tau \subseteq \mathbb{R}^d$ 为通过其置信度阈值的输入区域。对目标分布 $\mathcal{P}$, 用 $R_{\mathcal{P}}(f) = \mathbb{P}_{\mathcal{P}}(f(\mathbf{x}) \neq y)$ 表示任意候选分类器 f 的新样本风险。设 $\pi = \mathbb{P}_{\mathcal{P}}(\mathbf{x} \in \mathbf{X}_\tau) > 0$, 在筛选区域内分别考察伪标签自身的错误率, 以及 f 与伪标签不一致的概率:

$$\begin{aligned} e_\tau &= \mathbb{P}_{\mathcal{P}}(h(\mathbf{x}) \neq y \mid \mathbf{x} \in \mathbf{X}_\tau), \\ \tilde{R}_\tau(f) &= \mathbb{P}_{\mathcal{P}}(f(\mathbf{x}) \neq h(\mathbf{x}) \mid \mathbf{x} \in \mathbf{X}_\tau). \end{aligned} \quad (3.109)$$

若 f 预测错误, 它要么与 h 不一致, 要么沿用了 h 的错误, 因此

$$\{f(\mathbf{x}) \neq y\} \subseteq \{f(\mathbf{x}) \neq h(\mathbf{x})\} \cup \{h(\mathbf{x}) \neq y\}, \quad (3.110)$$

在 $\mathbf{X}_\tau$ 内应用并集界, 再把区域内的风险相加, 得到

$$\begin{aligned} R_{\mathcal{P}}(f) &\leq \pi(\tilde{R}_\tau(f) + e_\tau) \\ &\quad + \mathbb{P}_{\mathcal{P}}(f(\mathbf{x}) \neq y, \mathbf{x} \notin \mathbf{X}_\tau). \end{aligned} \quad (3.111)$$

因此, 即使 f 完全拟合了该区域的伪标签, 也不能据此消除 e_τ , 更没有控制区域外的错误。这个界描述固定一轮模型及其筛选区域的总体风险关系, 不是多轮自训练的风险递减定理; $\tilde{R}_\tau(f)$ 也不是有限伪标签集上的训练误差。采纳事件依赖模型, 历史伪标签又由不同轮次产生, 不能把 $|L| + |A|$ 直接当成独立真实标签的样本数来套用监督泛化界。

较高阈值能够减少采纳数量, 却不能消除系统性高置信度错误。控制伪标签权重与单轮规模、检验不同类别的接受率, 以及用保留的真实标签验证集比较扩充前后的性能, 分别约束影响强度、类别偏置与实际效果。验证样本不能同时作为被模型反复吸收的伪标签训练样本, 否则对自训练收益的估计会失去独立性。若未标注池混入未知类别, 或标注数据只覆盖少数容易区域, 还需要检查这些不匹配, 而不能只调低阈值以追求更多伪标签。

3.6.1.4 小结

自训练把已有分类器的部分预测转化为新增监督, 适合在保留原有训练和预测接口的情况下探索无标签数据的价值。它的额外成本包括对剩余池反复预测, 以及在不断扩大的训练集上重新拟合; 基分类器训练昂贵时, 这些成本并不小。最终模型仍按原分类器的方式预测新样本, 无须保留一个独立的传播图。

是否采用自训练, 主要取决于初始预测能否筛出足够可靠且有代表性的样本。标签极少时, 恰恰可能无法满足这一条件, 所以它不是所有冷启动任务的默认答案; 反过来, 具备持续验证和错误处理机制时, 也没有理由把它限定为只能短期使用。人工复核可以改善部分伪标签的质量, 但是

否需要、复核哪些样本，应由误判代价与可用预算决定，不能把这一环节当作普遍充分的安全保证。

3.6.2 Label Propagation

自训练通过基分类器决定哪些预测值得采纳；如果可信的信息主要来自样本之间的邻近关系，也可以直接在这些关系上传递标签。**标签传播** (label propagation) 把样本表示为图的节点，让已有标签沿相似边影响尚无标签的节点。Zhu 与 Ghahramani 在 2002 年的技术报告中给出了保持已知标签不变的传播方法⁷⁸。与只在已标注样本中寻找近邻相比，未标注点也参与形成传播路径，使标签能够沿弯曲的高密度区域传递；每轮恢复已知标签，则让它们持续提供监督，不会因反复平均而失去原有的类别信息。

本节采用与调和函数解释一致的随机游走记号，明确区分这种硬边界传播与后面介绍的软约束版本。

⁷⁸ X. Zhu, Z. Ghahramani, *Learning from Labeled and Unlabeled Data with Label Propagation*, tech. rep. CMU-CALD-02-107, Carnegie Mellon University, June 2002

3.6.2.1 模型结构

图模型把“哪些输入相似”转化成可计算的边权。令 $\mathcal{G} = (V, E, \mathbf{W})$ ，其中 $V = L \cup U$ ， $\mathbf{W} \in \mathbb{R}^{n \times n}$ 为非负对称权重矩阵， $\mathbf{W}_{i,j} = \mathbf{W}_{j,i} \geq 0$ ，且取 $\mathbf{W}_{i,i} = 0$ 。例如，可以先选出近邻边，再在相连节点上使用 RBF 相似度

$$\mathbf{W}_{i,j} = \begin{cases} \exp(-\gamma \|\mathbf{x}_i - \mathbf{x}_j\|_2^2), & \{i, j\} \in E, \\ 0, & \text{其他情形,} \end{cases} \quad (3.112)$$

其中 $\gamma > 0$ 控制相似度衰减。用 k 近邻关系构图时，单向近邻关系需要经过并集或互近邻等明确规则转成无向边，才能满足对称性。完全图保留所有样本对，稀疏图只保留选中的关系；两者不仅存储成本不同，也可能给出不同的分类结果。

每个节点的加权重记为 $\delta_i = \sum_j \mathbf{W}_{i,j}$ ，度矩阵满足 $\mathbf{D}_{i,i} = \delta_i$ 。在所有参与传播的节点度数为正时，定义

$$\mathbf{P} = \mathbf{D}^{-1} \mathbf{W}, \quad \mathbf{P}_{i,j} = \frac{\mathbf{W}_{i,j}}{\delta_i}. \quad (3.113)$$

矩阵 $\mathbf{P}$ 每行的和为 1，表示从一个节点沿边随机走向邻居的转移概率。传播时用这一行权重对邻居的标签信息求平均；权重大，邻居的影响也大。

为了同时处理 C 个类别，令 $\mathbf{F} \in \mathbb{R}^{n \times C}$ 保存节点得分， $\mathbf{f}_i = (\mathbf{F}_{i,1}, \dots, \mathbf{F}_{i,C})^\top$ 为节点 i 的得分向量。构造同形状的 $\mathbf{Y}$ ：若 $i \in L$ ，则 $\mathbf{Y}_{i,c} = \mathbb{1}\{y_i = c\}$ ；若 $i \in U$ ，则整行置零。有标签节点在每轮更新后都恢复到这份独热编码，这种固定边界的操作称为**硬钳制** (hard clamping)，也就是不允许传播改变已经给定的标签。

构图时必须检查标签信息能否到达每个待预测节点。零度无标签节点没有邻居,无法定义式(3.113)中的转移概率;一个连通分量若完全没有标签,即使每个节点度数都大于零,也无法确定任何类别。可以补充真实标签、依据可靠关系重新构图,或对这些节点明确拒绝预测。孤立的有标签节点保留原标签即可,不必参与传播。仅增加一个微小度数或自环,只解决部分数值形式问题,并没有给缺少监督的分量提供类别信息。

3.6.2.2 参数学习

标签传播没有固定维数的分类器参数要拟合,但要求出全部无标签节点的得分。下面假设零度节点已经处理,每个含无标签节点的连通分量至少含一个有标签节点。把 $\mathbf{F}$ 按 L 与 U 分成行块 $\mathbf{F}_L = \mathbf{F}_{L,:}$ 、 $\mathbf{F}_U = \mathbf{F}_{U,:}$,并对 $\mathbf{P}$ 作对应分块。硬钳制意味着 $\mathbf{F}_L^{(t)} = \mathbf{Y}_L$ 始终不变,因而只需迭代

$$\mathbf{F}_U^{(t+1)} = \mathbf{P}_{U,U}\mathbf{F}_U^{(t)} + \mathbf{P}_{U,L}\mathbf{Y}_L. \quad (3.114)$$

右侧第一项传递尚无标签节点之间的当前信息,第二项持续注入真实标签。通常取 $\mathbf{F}_U^{(0)} = \mathbf{0}$ 。这个硬钳制方案不需要再引入传播系数 α ,也不在有标签节点上附加一个有限权重的软拟合项。

若迭代达到固定点,移项便得到线性系统与形式上的闭式解

$$\begin{aligned} (\mathbf{I} - \mathbf{P}_{U,U})\mathbf{F}_U^* &= \mathbf{P}_{U,L}\mathbf{Y}_L, \\ \mathbf{F}_U^* &= (\mathbf{I} - \mathbf{P}_{U,U})^{-1}\mathbf{P}_{U,L}\mathbf{Y}_L. \end{aligned} \quad (3.115)$$

这里 $\mathbf{I}$ 为 $|U| \times |U|$ 单位矩阵。下一小节将证明,在上述图条件下逆矩阵存在,且任意初始化的迭代都收敛到同一个解。计算时通常直接求解线性系统,避免显式构造逆矩阵。Zhu、Ghahramani 与 Lafferty 给出了这一解的调和函数、图能量和随机游走解释⁷⁹。

图3.9给出一个可逐项核算的教学构造,并非实测数据。五个节点依次相连,每条无向边的权重为1;端点1固定属于类1,端点5固定属于类2,节点2、3、4没有标签。令 $p_i = \mathbf{F}_{i,1}^*$,由于每个内点恰有两个等权邻居,式(3.114)在固定点处变为

$$\begin{aligned} p_i &= \frac{p_{i-1} + p_{i+1}}{2}, \quad i = 2, 3, 4, \\ p_1 &= 1, \quad p_5 = 0. \end{aligned} \quad (3.116)$$

内点方程等价于 $p_{i+1} - p_i = p_i - p_{i-1}$,所以相邻节点的得分差必须相等。两端总共下降1,分到四条边上,每步下降1/4,得到

$$(p_1, p_2, p_3, p_4, p_5) = (1, 0.75, 0.5, 0.25, 0).$$

类2的得分满足相反的端点条件,故 $\mathbf{f}_i^* = (p_i, 1 - p_i)^\top$ 。节点2偏向类1,

⁷⁹ X. Zhu, Z. Ghahramani, J. Lafferty, *Semi-Supervised Learning Using Gaussian Fields and Harmonic Functions* In Proceedings of the Twentieth International Conference on Machine Learning, 2003, pp. 912–919


```

20: end for
21:  $\hat{y}_j \leftarrow \arg \max_c F_{j,c}, j \in U$ ; 并列取最小  $c$ 
22: return  $F, \hat{y}_U, \text{converged}$ 

```

算法先把 G 保存成最新的 F_U ，再判断是否退出，因此即使本轮达到容限，也会返回新得分而不是上一轮的值。相邻迭代差小是一种可操作的停止指标，不直接给出距离精确解的统一误差界；当传播很慢时，还需结合线性系统残差与条件数判断数值精度。最终类别由得分比较决定，接近平局的节点尤其需要保留得分与未收敛状态。

3.6.2.3 理论分析

收敛性分析 硬钳制传播能够收敛，关键不是“每个节点都直接连着标签”，而是未标注节点经过若干步能够到达有标签节点。 $P_{U,U}$ 每一行的和至多为 1，其中某些行可以恰好等于 1，因为对应节点暂时只有无标签邻居。要证明收缩，需要考察多步传播后仍然留在 U 中的总权重。

定理 3.13 硬钳制传播的唯一解 设图有限、边权非负且对称，所有参与传播的节点度数为正， U 非空，且每个含无标签节点的连通分量至少含一个有标签节点。则 $\rho(P_{U,U}) < 1$ ，其中 ρ 表示谱半径。式 (3.114) 从任意初始得分出发，都收敛到式 (3.115) 中的唯一固定点。

证明. 从每个 $j \in U$ 出发，选择一条到达 L 的正权路径，并在首次到达 L 时停止。有限图中这些路径长度有一个共同上界 m ，沿各路径行走的概率均为正，其最小值记为 $\epsilon > 0$ 。于是，无论从哪个无标签节点出发，在 m 步以内命中 L 的概率都至少为 ϵ 。这说明

$$\|P_{U,U}^m\|_\infty \leq 1 - \epsilon, \quad \rho(P_{U,U})^m \leq 1 - \epsilon < 1.$$

因而 $P_{U,U}^t$ 趋于零，Neumann 级数收敛，且

$$(I - P_{U,U})^{-1} = \sum_{t=0}^{\infty} P_{U,U}^t.$$

迭代展开为

$$F_U^{(t)} = P_{U,U}^t F_U^{(0)} + \sum_{s=0}^{t-1} P_{U,U}^s P_{U,L} Y_L.$$

第一项消失，第二项趋于所述固定点。逆矩阵存在，也排除了其他固定点。 ■

还可以从最优化的角度解释同一个解。相邻节点的得分差越大，图上的

不平滑程度越高。令 $\mathbf{L}_g = \mathbf{D} - \mathbf{W}$ 为**图拉普拉斯矩阵** (graph Laplacian), 它把这种局部差异汇总成二次型。固定真实标签边界后, 求解的**狄利克雷能量** (Dirichlet energy) 最小化问题为

$$\begin{aligned} \min_{\mathbf{F}: \mathbf{F}_L = \mathbf{Y}_L} \mathcal{E}(\mathbf{F}) &= \frac{1}{2} \sum_{i,j=1}^n \mathbf{W}_{i,j} \|\mathbf{f}_i - \mathbf{f}_j\|_2^2 \\ &= \text{tr}(\mathbf{F}^\top \mathbf{L}_g \mathbf{F}). \end{aligned} \quad (3.117)$$

第4.3.1节的谱聚类与第5.3.3节的拉普拉斯特征映射复用图拉普拉斯和谱工具, 但输出分别是离散簇分配与连续低维坐标; 这里的标签传播则在已知类别语义下求类别得分。共享图结构不意味着三个任务使用相同的输出约束。

有标签节点在这里是固定边界, 不是可以通过支付有限罚项而改变的变量。对未知行块求导并令其为零, 得到

$$\begin{aligned} (\mathbf{L}_g)_{U,U} \mathbf{F}_U &= -(\mathbf{L}_g)_{U,L} \mathbf{Y}_L \\ &= \mathbf{W}_{U,L} \mathbf{Y}_L. \end{aligned} \quad (3.118)$$

因为 $(\mathbf{L}_g)_{U,U} = \mathbf{D}_{U,U} - \mathbf{W}_{U,U}$, 左乘 $\mathbf{D}_{U,U}^{-1}$ 就回到式 (3.115) 的线性系统。

这个驻点也是唯一最小值, 而不只是一个形式上的导数解。取任意无标签节点上的非零向量 $\mathbf{z}$, 把它扩展成在 L 上为零的全图向量 $\tilde{\mathbf{z}}$, 则

$$\mathbf{z}^\top (\mathbf{L}_g)_{U,U} \mathbf{z} = \frac{1}{2} \sum_{i,j} \mathbf{W}_{i,j} (\tilde{z}_i - \tilde{z}_j)^2.$$

右侧若为零, 向量在每个正权连通分量上就必须为常数。每个涉及 U 的分量又含一个值为零的标签边界, 因此这些常数只能全部为零, 与 $\mathbf{z} \neq \mathbf{0}$ 矛盾。故未标记主子块正定, 能量对 $\mathbf{F}_U$ 严格凸。这同时解释了为什么完全无标签的分量会破坏唯一性: 在这种分量上, 任意常值向量都不增加图能量。

得分的概率含义也需要依赖这些条件。从一个无标签节点按 $\mathbf{P}$ 行走, 并在首次碰到有标签节点时停止, $\mathbf{F}_{j,c}^*$ 等于首次命中的标签属于类 c 的概率。由于最终命中 L 的概率为 1, 精确解各行非负且行和为 1。若从零初始化, 有限轮得分只累积了相应步数内的命中概率, 行和可能还小于 1; 一般不能把尚未收敛的得分直接当成归一化概率。即便在极限处, 这也是给定图上的命中概率, 不自动等于真实任务中校准的类别后验。

泛化分析 优化的唯一性没有检验图是否表达了正确的类别关系。**平滑假设** (smoothness assumption) 在这里意味着强相似边连接的节点应具有相近标签得分; 若文档按写作风格聚集却按主题分类, 这个假设就可能失效。跨类强边会把错误信息传到邻域, 错误的标签边界还会被硬钳制持续

保留。高维距离失真时,特征标准化、降维或度量学习可以改善构图的候选表示,但这些处理同样需要验证,不能由线性系统收敛来证明其合理性。

这里还要区分两种评价对象。对非空 U , 在训练之外取得真实标签后, 可以计算

$$\hat{R}_U = \frac{1}{|U|} \sum_{j \in U} \mathbb{1}\{\arg \max_c F_{j,c}^* \neq y_j\}. \quad (3.119)$$

其中并列得分仍按最小类别编号处理, y_j 只用于评价。这个误差针对已经参与构图的输入, 不是对未来独立样本风险的直接估计。要讨论新样本, 还必须定义归纳扩展 $h_g(\mathbf{x})$, 即规定新输入如何连接到图、怎样由图上得分产生预测, 以及是否重新求解; 这时才有相应的风险 $R_{\mathcal{P}}(h_g) = \mathbb{P}_{\mathcal{P}}(h_g(\mathbf{x}) \neq y)$ 。

前述定理没有对 $R_{\mathcal{P}}(h_g)$ 给出上界: 它既未规定这种扩展, 也未假设新样本与图上标签之间的统计关系。若要建立随样本数变化的风险保证, 还需把构图规则、标签覆盖和类别平滑性等条件与目标分布联系起来。对一个给定图求出唯一解, 只解决了得分怎样确定, 不能替代这些条件。

3.6.2.4 小结

标签传播适合相似关系本身可信的任务, 例如有可靠连接语义的节点分类, 或用局部外观关系传播图像块标签。其基本输出是当前图上各节点的得分, 适合面向这批输入作出预测; 若任务持续接收新输入, 前述归纳扩展也应纳入模型设计和评价。

计算成本取决于图的稀疏性与求解精度, 而不是一个固定的节点数分界。记 $\text{nnz}(\mathbf{W})$ 为非零权重数, 稀疏图一次传播的主要乘法成本为 $O(\text{nnz}(\mathbf{W})C)$, 存储主要为 $O(\text{nnz}(\mathbf{W}) + nC)$; 总时间还要乘以迭代次数, 并另计构图成本。完全图的存储为 $O(n^2)$, 直接计算所有欧氏距离通常需 $O(n^2d)$ 。即使图很稀疏, 连接标签区域的边过弱, 也会使 $\rho(\mathbf{P}_{U,U})$ 接近 1, 导致传播缓慢。

可以利用稀疏线性求解器, 或在合适的相似度矩阵上使用 **Nyström 近似** (Nyström approximation), 即选取少量代表列来构造低秩近似, 减少矩阵运算。但近似相似度不一定保留原图的非负边权、连通关系与硬边界解; 采用近似后应重新检查这些条件和求解误差。图上的唯一解、数值上的近似精度以及分类准确率, 是三个需要分别评价的问题。

3.6.3 TSVM

图传播直接平滑节点得分; 若希望保留 SVM 的分类函数, 则可以让无标签样本参与选择大间隔边界。**直推支持向量机** (transductive support vector machine, TSVM) 同时选择分类器与当前未标注样本的标签, 使两类样本共同约束间隔。Joachims 在 1999 年的文本分类研究中给出了有代表性的目标与实用求解算法。其相关性反馈任务说明了这一选择的背景: 用户只

标注少量检索结果是否相关，其余待分类文档却已经构成一个给定的文档库。于是，这些文档不必等到训练结束后才交给分类器，而可以在训练时通过自身的位置参与确定间隔边界⁸⁰。

这里的**直推学习** (transductive learning, 也称转导学习) 指利用当前已给定的待预测输入，直接推断这批输入的标签；它与面向未来新输入评价预测规则的归纳设定有所区别。TSVM 仍会得到一个 SVM 分类函数，所以从计算上也能处理新样本。区别在于哪些输入参与了训练，以及理论或实验评价针对哪批预测，而不是算法是否能够写出一个函数。

⁸⁰ T. Joachims, *Transductive Inference for Text Classification using Support Vector Machines* In Proceedings of the 16th International Conference on Machine Learning, 1999, pp. 200–209

3.6.3.1 模型结构

本小节使用二分类标签 $\{-1, +1\}$ 。令 $g(\mathbf{x}) = \mathbf{w}^\top \phi(\mathbf{x}) + b$ 为决策分数， ϕ 为选定的特征映射；线性 SVM 取 $\phi(\mathbf{x}) = \mathbf{x}$ 。标准软间隔 SVM 只要求已标注样本尽量满足 $y_i g(\mathbf{x}_i) \geq 1$ 。TSVM 还为每个 $j \in U$ 引入一个待选择的离散标签 y_j^u ，并为相应间隔约束配置松弛变量 ξ_j^u 。其目标可写为

$$\begin{aligned} \min_{\mathbf{w}, b, \mathbf{y}^u, \boldsymbol{\xi}} \quad \mathcal{J} = & \frac{1}{2} \|\mathbf{w}\|_2^2 + \lambda_s \sum_{i \in L} \xi_i \\ & + \lambda_u \sum_{j \in U} \xi_j^u, \end{aligned} \quad (3.120)$$

其中 $\mathbf{y}^u$ 收集无标签节点的离散标签， $\boldsymbol{\xi}$ 收集两类松弛变量， $\lambda_s > 0$ 与 $\lambda_u \geq 0$ 分别控制有标签项和无标签项的惩罚。约束为

$$\begin{aligned} y_i g(\mathbf{x}_i) &\geq 1 - \xi_i, & \xi_i &\geq 0, & i &\in L, \\ y_j^u g(\mathbf{x}_j) &\geq 1 - \xi_j^u, & \xi_j^u &\geq 0, & j &\in U, \\ y_j^u &\in \{-1, +1\}, & & & j &\in U, \\ \sum_{j \in U} \frac{1 + y_j^u}{2} &= r. \end{aligned} \quad (3.121)$$

最后一行固定无标签样本中的正类标签数量 r 。本节讨论 $|U| \geq 2$ 且 $1 \leq r \leq |U| - 1$ 的非退化情形； $\lambda_u = 0$ 或 U 为空时，分类器训练回到纯监督 SVM。

类别数量约束来自一个实际困难：无标签样本本身不能说明哪一侧应有多少样本。若只要求间隔大，模型可能把几乎全部未标注样本放到同一类，从而得到不符合任务的划分。**类别平衡约束** (class-balance constraint) 把对类别组成的外部知识加入优化，它不要求两类数量相等，而是固定或限制可接受的比例。可以根据可信先验选择 r ，也可以规定 $r_{\min} \leq \sum_j (1 + y_j^u)/2 \leq r_{\max}$ 。由少量已标注样本估计比例时，需要考虑抽样偏差；错误的比例约束同样会损害结果。

约束的是待优化标签的数量，不是带松弛的分类器最终必须恰好预测 r

个正类。个别样本仍可能被分错或落在间隔内。明确这一区别，才能理解为什么固定比例的标签交换是可行操作，却不保证每次训练后的正预测比例完全不变。

无标签项怎样影响边界，可以暂时去掉数量约束来观察。对给定分数 s ，若允许独立选择二分类标签，最小的无标签合页损失为

$$\min_{y \in \{-1, +1\}} [1 - ys]_+ = [1 - |s|]_+, \quad (3.122)$$

其中 $[a]_+ = \max\{a, 0\}$ 。这项损失惩罚分数靠近零的无标签样本，却不预先规定它们应落在哪一侧。在合适的表示下，若大量输入集中在少数区域，让边界避开这些区域就能减少此项损失。这是**低密度分离假设**（low-density separation assumption）的作用：类别分界应经过输入较少的区域，而不是切开高密度的同类区域。恢复类别数量约束后，各个标签选择相互耦合，不能再逐样本独立最小化。

3.6.3.2 参数学习

固定 $\mathbf{y}^u$ 以后，式 (3.120) 就是具有不同样本惩罚的软间隔 SVM，可以沿用相应凸优化求解器。困难在于标签本身还要选择：固定正类数 r 时有 $\binom{|U|}{r}$ 种标签配置，通常无法逐一求解比较。实用算法从监督 SVM 出发，交替改善标签与分类器，并逐步提高 λ_u ，使无标签数据的影响从弱变强。

初始化也要满足数量约束。先在 L 上训练监督 SVM，按它对 U 的决策分数排序，把分数最高的 r 个样本暂定为正类，其余为负类；分数并列时按样本索引排序。直接使用监督分类器的正负预测，不一定能得到规定的正类数，因此不能替代这一步。

在固定 $\lambda_u > 0$ 的一轮内，可以交换一个当前正类样本 a 与负类样本 b 的标签。这样正类总数不变，只需判断交换是否有利。记 $\ell_h(s) = [1 - s]_+$ ，在当前分类器分数不变时，交换带来的无标签损失变化为

$$\begin{aligned} \Delta_{a,b} = & \ell_h(-g(\mathbf{x}_a)) + \ell_h(g(\mathbf{x}_b)) \\ & - \ell_h(g(\mathbf{x}_a)) - \ell_h(-g(\mathbf{x}_b)). \end{aligned} \quad (3.123)$$

若 $\Delta_{a,b} < 0$ ，仅交换标签并相应调整松弛变量，就已经降低了目标中的无标签项；随后重新求解固定标签的 SVM，目标值只会进一步降低或保持不变。这个判据给出一类易于检查的下降交换，而不是穷尽所有可能使重训结果改善的标签变化。

算法3.8采用这一下降判据说明求解过程。FitSVM($\mathbf{y}^u, \lambda_u$) 表示在当前固定标签下，用有标签惩罚 λ_s 和无标签惩罚 λ_u 完整求解 SVM。原始实现还可以为未标注正负类使用不同惩罚；这里用统一的 λ_u 突出类别平衡、交换与逐步加权的的关系。

算法 3.8 固定类别数量的 TSVM 逐步加权

输入： 含两个类别的训练索引 L ，无标签索引 U

输入： $|U| \geq 2$ ，正类数量 $1 \leq r \leq |U| - 1$

输入： $\lambda_s > 0$ ，目标 $\lambda_u^{\text{final}} > 0$

输入： 初值 $\lambda_u^{(0)} > 0$ ，倍率 $q > 1$ ，容限 $\varepsilon \geq 0$

输出： 分类器 g 及离散标签 $\mathbf{y}^u$

- 1: 在 L 上训练监督 SVM，得到 g
- 2: 按 g 的分数将 U 中前 r 个样本标为正，其余标为负
- 3: $\lambda_u \leftarrow \min\{\lambda_u^{(0)}, \lambda_u^{\text{final}}\}$
- 4: **while** 尚未在目标惩罚值下完成训练 **do**
- 5: $g \leftarrow \text{FitSVM}(\mathbf{y}^u, \lambda_u)$
- 6: **while** 存在正负标签对 (a, b) 使 $\Delta_{a,b} < -\varepsilon$ **do**
- 7: 交换 y_a^u 与 y_b^u
- 8: $g \leftarrow \text{FitSVM}(\mathbf{y}^u, \lambda_u)$
- 9: **end while**
- 10: **if** $\lambda_u = \lambda_u^{\text{final}}$ **then**
- 11: **break**
- 12: **end if**
- 13: $\lambda_u \leftarrow \min\{q\lambda_u, \lambda_u^{\text{final}}\}$
- 14: **end while**
- 15: **return** $g, \mathbf{y}^u$

逐步增加无标签惩罚常称为**退火** (annealing)：先在真实标签主导的目标上取得初始解，再逐渐增加无标签约束的影响。这里的每个阶段都先训练并完成交换搜索，再判断是否已经达到最终惩罚值。即使某次更新刚好把惩罚设为目标值，也仍需进入下一阶段训练，不能在更新数值后直接返回旧模型。若另设总时间或阶段数量上限，应把提前终止作为未完成目标惩罚训练的状态返回。

这一过程使用上一阶段的结果作初始化，可视为一种延续求解策略，但离散标签变化可能使解发生跳变，不保证存在一条光滑的解路径。退火倍率、初始标签和交换搜索方式会改变最终结果，适合通过多个合理初始化与独立验证比较，而不是把逐步加权当作全局最优算法。

3.6.3.3 理论分析

收敛性分析 固定标签子问题的凸性，不会使标签与参数联合优化也变凸。式 (3.122) 已经显示出其中的非凸性：在 $s = -1$ 和 $s = 1$ 处损失均为零，在中点 $s = 0$ 处却为 1，不满足凸函数的中点不等式。实际问题又包含离散标签及其数量限制，因而是连续变量与离散变量耦合的非凸优化问题。求解一个固定标签的 SVM 与搜索标签配置，是两项不同的工作。

在固定惩罚值下，算法的有限终止可以有一个明确但有限的保证。假设每次固定标签的 SVM 都求到全局最小值，并且只接受式 (3.123) 所给出的

严格下降交换。令 $V(\mathbf{y}^u)$ 为当前标签配置对应的最优目标值，则一次接受交换后有

$$V(\mathbf{y}_{\text{new}}^u) \leq V(\mathbf{y}_{\text{old}}^u) + \lambda_u \Delta_{a,b} < V(\mathbf{y}_{\text{old}}^u).$$

可行标签配置有限，因此不能在严格下降过程中反复回到同一配置，内层搜索最终会停止。倍率 $q > 1$ 并在目标值处截断，也保证外层惩罚阶段有限。这一结论依赖精确子问题求解与严格下降；使用数值近似时，需要检查重训后的实际目标变化，不能只根据理想化推导接受任意交换。

停止只说明当前搜索规则没有找到可接受的改进。即使任何交换在固定 g 时都不下降，也仍可能存在交换后充分重训才改善的解，或者需要同时改变多个标签才能到达的更好配置。因此，这个停止条件既不保证全局最优，也不保证对所有单对交换重训都已最优。不同 λ_u 阶段之间的目标函数也不同，跨阶段的目标值不构成同一目标下的下降序列。

泛化分析 统计上的风险来自另一组条件。如果两个真实类别在同一高密度区域内严重重叠，正确的分类边界可能就需要穿过该区域。较大的 λ_u 却会奖励避开它的边界，导致无标签数据拉低分类性能。错误的类别比例、未标注池中的未知类别，以及只对局部区域可靠的初始监督模型，也可能产生类似损害。优化更充分并不能修复失效的分布假设，有时反而会更彻底地实现一个不适合任务的目标。

因而，TSVM 的效果应与同样特征、同样有标签训练集上的监督 SVM 比较，并用没有参与调参的真实标签评价。允许训练时看到当前待预测输入，是直推实验设定的一部分；它不能被报告成对完全未见输入的同等保证。若最终用途是归纳预测，还需要另外检查新样本上的表现。

一种不依赖 TSVM 优化过程的检查，是在训练与调参全部完成后，固定最终分类规则 f ，再用 $m \geq 1$ 个独立来自目标分布 $\mathcal{P}$ 的真实标注测试样本评价。这些样本的输入也不参与训练、特征拟合或模型选择。记其零一测试误差为 $\hat{R}_{\text{test}}(f)$ ；条件于训练所得的 f ，每个测试错误都是均值为 $R_{\mathcal{P}}(f)$ 的独立 Bernoulli 变量。由第二卷“基础、理论和可信性”的“二分类学习的可学习性”章中的 Hoeffding 不等式，对 $0 < \delta < 1$ ，至少以 $1 - \delta$ 的概率有

$$R_{\mathcal{P}}(f) \leq \hat{R}_{\text{test}}(f) + \sqrt{\frac{\log(2/\delta)}{2m}}. \quad (3.124)$$

这个界把独立测试误差联系到新样本风险，也适用于固定后的自训练分类器或已定义归纳扩展的图分类器。它不是半监督方法优于监督基线的保证；界中的 m 只计独立测试样本，不能换成训练时使用的无标签数量。反复查看这批测试结果后再选择模型，会破坏上述固定分类器的前提，需要另作模型选择校正或保留新的独立测试集。

3.6.3.4 小结

TSVM 保留了 SVM 的决策函数，把变化集中在训练目标与离散标签搜索中。预测新输入时仍计算 $g(\mathbf{x})$ 并取其符号；分数恰为零时，应使用预先约定的并列规则。它适用于大间隔与低密度分离有合理联系、类别组成可约束的任务，而不是只要无标签样本多就值得引入。

训练开销主要来自反复求解带权 SVM 与搜索标签交换，受到基求解器、核矩阵规模、惩罚阶段和搜索策略共同影响。类别数量约束避免部分退化解，逐步加权改善求解起点的利用方式，但都不能保证准确率超过监督基线。后面的安全半监督方法进一步研究怎样限制可能的损害，其保证仍有特定前提，不能作为 TSVM 在任意数据上有效的替代条件。

3.6.4 模型对比与总结

本小节先比较 Self-Training、Label Propagation 与 TSVM，再补充生成式 EM、多视图训练、软传播、流形正则化和安全选择等代表性扩展。三种基本方法使用的是同一类额外资源，即没有可用标签的输入，但它们从中提取的信息不同。自训练借助现有模型选择补充监督，标签传播把相似关系转成得分平滑约束，TSVM 让输入分布参与间隔边界的选择。表3.5还加入生成式 EM 入口；这些机制可以共享假设，也可以组合，不能视为彼此互不重叠的分类。

方法	无标签数据怎样参与	关键条件与代价
Self-Training	筛选预测作伪标签，反复训练原分类器	采纳的预测应可靠；需反复预测与重训，警惕确认偏差。
Label Propagation	在固定标签边界下求图上调和得分	图应反映类别关系，且无标签分量能达到标签；成本依赖边数与求解精度。
TSVM	联合选择离散标签与大间隔分类器	低密度分离及类别数量约束应合理；需要非凸标签搜索与多次 SVM 训练。
生成式 EM	把未知类别视为潜变量，按类别软后验累计期望统计量	联合模型应足够贴合输入与类别；EM 只保证相应似然的局部改进。

表 3.5 四种半监督分类机制的比较。表中列的是使用信息的方式与主要限制，不构成准确率或计算复杂度从低到高的排序。前三行对应本节完整展开的模型，生成式 EM 行提供与概率分类模型相连的最小入口。

生成式半监督方法从另一条路线利用未标注输入。设联合模型为 $p_{\theta}(\mathbf{x}, y)$ ，有标签样本直接贡献输入与类别的联合对数似然，未标注样本

则只贡献输入的边缘对数似然：

$$\ell(\theta) = \sum_{i \in L} \log p_{\theta}(\mathbf{x}_i, y_i) + \sum_{j \in U} \log \sum_{c=1}^C p_{\theta}(\mathbf{x}_j, c).$$

在这个模型中，全部输入与全部类别合称**完全数据**（complete data），其中包括实际未观测的类别；它不表示已有记录的字段都无缺失。EM 在训练时把 U 中的未知类别作为潜变量处理。E 步用当前参数计算软后验 $q_j(c) = p_{\theta^{(t)}}(y = c | \mathbf{x}_j)$ ；一般的 M 步并不等同于更新类别计数，而是最大化当前软后验下的期望完全数据对数似然。记

$$\begin{aligned} Q(\theta | \theta^{(t)}) &= \sum_{i \in L} \log p_{\theta}(\mathbf{x}_i, y_i) \\ &\quad + \sum_{j \in U} \sum_{c=1}^C q_j(c) \log p_{\theta}(\mathbf{x}_j, c), \\ \theta^{(t+1)} &\in \arg \max_{\theta} Q(\theta | \theta^{(t)}). \end{aligned}$$

只有对多项式 NB 这类以类别与类别词频为充分统计量的模型，M 步才可以解释为把 $q_j(c)$ 作为分数类别计数，与真实标签统计量一起更新先验和类条件参数。此时，未标注文档的词频按 $q_j(c)$ 分配给各类别，而不是先固定成一个不可更改的硬伪标签。Nigam 等在文本分类中给出了这一路线的代表性实现⁸¹。

精确 E 步和充分求解的 M 步保证相应观测似然不下降⁸²。这一结论只针对选定生成模型和当前局部解，不能推出分类风险必然下降。模型失配时，大量未标注输入会加强对错误边缘结构的拟合，甚至使分类性能劣于只使用标签的基线；Cozman 与 Cohen 给出了这一现象的直接分析与实验⁸³。当潜变量不止类别，或后验不能闭式计算时，还需要结合具体图结构选择精确或近似推断；第3部分提供概率图模型的统一语境，本节不展开这些推断细节。

计算代价也没有固定的递增次序。多次重训昂贵的基分类器，可能比在稀疏图上传播更耗时；完全图的构建和存储，也可能超过线性 SVM 的多阶段训练；生成式 EM 则需反复计算未标注样本的后验并更新参数。选型需要同时考虑样本数、特征维数、类别数、边数、基求解器与迭代次数。已有稳定分类器时，自训练便于复用；关系图本身可信时，标签传播便于直接利用；需要保留间隔分类函数且分离假设合理时，TSVM 提供另一种选择；联合模型可信且软类别统计量可计算时，生成式 EM 提供概率路线。是否值得使用，都要回到相同评价条件下与监督基线的比较。

自训练的一个薄弱处是同一个模型既提出标签，又把它们作为后续训练依据。如果输入天然具有两种互补描述，可以让不同视图的模型提供监督。**协同训练**（co-training）分别在两个视图上训练分类器，再让一个分

⁸¹ K. Nigam, A. K. McCallum, S. Thrun, T. Mitchell, *Text Classification from Labeled and Unlabeled Documents using EM* In Machine Learning, 2000, vol. 39, no. 2–3, pp. 103–134

⁸² A. P. Dempster, N. M. Laird, D. B. Rubin, *Maximum Likelihood from Incomplete Data via the EM Algorithm* In Journal of the Royal Statistical Society: Series B (Methodological), 1977, vol. 39, no. 1, pp. 1–38

⁸³ F. G. Cozman, I. Cohen, *Unlabeled Data Can Degrade Classification Performance of Generative Classifiers* In Proceedings of the Fifteenth International Florida Artificial Intelligence Research Society Conference, 2002, pp. 327–331

类器选出的高置信度标签供另一个使用。Blum 与 Mitchell 在 1998 年的研究中使用网页正文与指向该网页的链接文字作为两种描述；其理论设定包括每个视图都足以确定类别，以及给定类别后两视图条件独立⁸⁴。

这两个条件承担不同作用：视图充分性使每个模型有可能独立完成任任务，条件独立性则限制两视图以相同方式出错的关系。互相提供伪标签并不等于彼此总能纠错；若两视图共享同一种偏差，错误仍可能相互强化。实际数据的视图可能相关，也可能没有自然的划分，此时仍可考察协同训练的效果，但不能直接套用强视图假设下的理论结论。

没有两种天然视图时，也可以通过重采样构造多个分类器。**三训练** (tri-training) 使用三个模型，并让其中两个的一致预测为第三个提供候选伪标签。Zhou 与 Li 在 2005 年提出的方法用 bootstrap 样本初始化模型，三个分类器可以使用相同特征和相同学习算法；最终预测通过三者投票得到⁸⁵。

三训练中的一致意见只是候选生成条件。原算法还利用有标签数据估计两个“提供标签”的模型在一致样本上的错误情况，并结合候选数量控制新增监督的错误负担；必要时对候选集采样，满足更新条件后才重训接收标签的模型。每个模型使用自己的临时伪标签集，与原始有标签集结合训练，而不是把所有一致预测永久变成真实标签。重采样制造的差异能否带来有用互补，仍受样本覆盖与模型错误相关性影响。

图方法的另一项选择是是否始终保留原标签。硬钳制适合把标签视为可信边界，但标签本身有噪声时，可能希望邻域信息也能调整有标签节点。Zhou 等人在 2003 年的局部与全局一致性方法中给出了软约束传播及其正则化解释⁸⁶。这类**标签扩散** (label spreading) 方法使节点在邻域平滑与贴近初始标签之间折中。

在所有节点度数为正的非负对称图上，定义

$$\mathbf{S} = \mathbf{D}^{-1/2} \mathbf{W} \mathbf{D}^{-1/2}, \quad \mathbf{L}_{\text{sym}} = \mathbf{I} - \mathbf{S}. \quad (3.125)$$

$\mathbf{S}$ 是对称归一化邻接矩阵， $\mathbf{L}_{\text{sym}}$ 才是对称归一化拉普拉斯矩阵。 $\mathbf{S}$ 的特征值位于 $[-1, 1]$ ，但不一定非负：两个节点以一条边相连时， $\mathbf{S}$ 的特征值就是 1 和 -1 。因此，支撑正则化目标凸性的是 $\mathbf{L}_{\text{sym}}$ 的半正定性，而不是 $\mathbf{S}$ 半正定。

沿用未标记行置零的初始矩阵 $\mathbf{Y}$ ，软约束目标为

$$\min_{\mathbf{F}} \quad \text{tr}(\mathbf{F}^T \mathbf{L}_{\text{sym}} \mathbf{F}) + \mu \|\mathbf{F} - \mathbf{Y}\|_{\mathbf{F}}^2, \quad \mu > 0. \quad (3.126)$$

第一项约束按度数归一化后的得分在图上平滑，第二项覆盖全部节点，而不只覆盖 L 。在未标记节点上， $\mathbf{Y}$ 为零，所以这一项也在约束得分大小。对

⁸⁴ A. Blum, T. Mitchell, *Combining Labeled and Unlabeled Data with Co-Training* In Proceedings of the Eleventh Annual Conference on Computational Learning Theory, 1998, pp. 92–100

⁸⁵ Z.-H. Zhou, M. Li, *Tri-Training: Exploiting Unlabeled Data Using Three Classifiers* In IEEE Transactions on Knowledge and Data Engineering, 2005, vol. 17, no. 11, pp. 1529–1541

⁸⁶ D. Zhou, O. Bousquet, T. N. Lal, J. Weston, B. Schölkopf, *Learning with Local and Global Consistency* In Advances in Neural Information Processing Systems, 2003, pp. 321–328

目标求导并令其为零, 得到 $[(1 + \mu)\mathbf{I} - \mathbf{S}]\mathbf{F} = \mu\mathbf{Y}$ 。令 $\alpha = 1/(1 + \mu)$, 则

$$\begin{aligned}\mathbf{F}^{(t+1)} &= \alpha\mathbf{S}\mathbf{F}^{(t)} + (1 - \alpha)\mathbf{Y}, \\ \mathbf{F}^* &= (1 - \alpha)(\mathbf{I} - \alpha\mathbf{S})^{-1}\mathbf{Y}.\end{aligned}\quad (3.127)$$

由于 $0 < \alpha < 1$ 且 $\rho(\mathbf{S}) \leq 1$, 有 $\rho(\alpha\mathbf{S}) < 1$, 这一次收敛来自显式收缩系数。迭代中所有节点都按同一公式更新, 有标签行也不再恢复成 $\mathbf{Y}_L$ 。若重新施加硬钳制, 就改变了优化问题及固定点, 不能继续使用这里的全图解。

α 增大时, 图平滑相对于标签拟合的作用增强, 某些含噪标签可以被邻居信息修正, 也可能把本来正确的少数类标签过度平滑。软得分的行和通常不等于 1; 按行归一化可以服务于展示或分类接口, 但不会自动得到校准概率。完全没有标签的分量在这个软目标下会得到零解, 数值上的唯一性仍未赋予它类别信息。因此, 软约束的灵活性要与标签噪声和图质量一同评价。

如果希望同时使用图结构并直接预测新输入, 可以把图能量施加在分类函数上。**拉普拉斯支持向量机** (Laplacian SVM) 在监督合页损失之外加入图正则项, 要求相似样本上的函数值接近。

以下讨论二分类, 将有标签样本的类别编码为 $y_i \in \{-1, +1\}$ 。设 g 属于核 K 的再生核 Hilbert 空间 $\mathcal{H}_K$, b 为偏置, $\mathbf{s}$ 收集全部样本的分数 $s_i = g(\mathbf{x}_i) + b$ 。采用与本章 SVM 一致的惩罚记号, 一种相应目标是

$$\begin{aligned}\min_{g \in \mathcal{H}_K, b} \quad & \frac{1}{2} \|g\|_{\mathcal{H}_K}^2 + \lambda_s \sum_{i \in L} [1 - y_i s_i]_+ \\ & + \frac{\lambda_g}{n^2} \mathbf{s}^\top \mathbf{L}_g \mathbf{s},\end{aligned}\quad (3.128)$$

其中 $\lambda_g \geq 0$ 控制图平滑。真实标签只出现在合页损失中, 但图项同时使用 L 与 U 的输入关系; 这里不为 U 引入需要离散搜索的标签变量。固定核、图及其超参数后, 若核为正定核且图拉普拉斯矩阵半正定, 这个目标就是凸的, 其优化性质与 TSVM 的离散非凸搜索不同。

Belkin、Niyogi 与 Sindhwani 在 2006 年的流形正则化框架中系统给出了这一构造⁸⁷。

相应解可表示为 $g(\mathbf{x}) = \sum_{i=1}^n a_i K(\mathbf{x}_i, \mathbf{x})$, 展开中可以包含有标签和无标签样本。对新输入, 按 $\hat{y}(\mathbf{x}) = \text{sign}(g(\mathbf{x}) + b)$ 判类; 沿用第 3.1.3.1 节的约定, 零得分预测为 +1。这样无须先把新输入纳入原图求出一个新节点得分, 但仍需承担核展开的存储和计算成本。这里的标量得分与合页损失只对应二分类, 多分类须另行组织类别竞争; 凸性也只保证对给定目标的求解性质, 并不能证明图结构正确或分类必然优于监督 SVM。

针对无标签数据可能损害监督基线的问题, **安全半监督支持向量机** (safe semi-supervised support vector machine, S4VM) 把候选划分之间的不确定

⁸⁷ M. Belkin, P. Niyogi, V. Sindhwani, *Manifold Regularization: A Geometric Framework for Learning from Labeled and Unlabeled Examples* In Journal of Machine Learning Research, 2006, vol. 7, pp. 2399–2434

性纳入决策。Li 与 Zhou 在 2011 年的方法中探索多组有代表性的大间隔划分，再按照相对于监督基线的最坏净收益选择预测。这种“安全”是对候选标签集合作出覆盖假设后的条件保证，而不是任意分布上的无条件保证⁸⁸。

这个条件可以用有限样本上的比较明确说明。令 $\mathbf{y}^0$ 为监督 SVM 对 U 的预测， $\mathbf{V} \subseteq \{-1, +1\}^{|U|}$ 为搜索得到的非空候选标签向量集合， $\hat{\mathbf{y}}$ 为拟选择的输出。相对于某个候选真值 $\mathbf{v} \in \mathbf{V}$ ，定义把基线错误改正的数量 G 和把基线正确预测改错的数量 B ：

$$\begin{aligned} G(\hat{\mathbf{y}}, \mathbf{v}) &= \sum_{j \in U} \mathbb{1}\{y_j^0 \neq v_j, \hat{y}_j = v_j\}, \\ B(\hat{\mathbf{y}}, \mathbf{v}) &= \sum_{j \in U} \mathbb{1}\{y_j^0 = v_j, \hat{y}_j \neq v_j\}. \end{aligned} \quad (3.129)$$

给损害项一个不小于 1 的权重 κ ，就可以寻找最坏净收益尽可能大的预测：

$$\max_{\hat{\mathbf{y}} \in \{-1, +1\}^{|U|}} \min_{\mathbf{v} \in \mathbf{V}} \{G(\hat{\mathbf{y}}, \mathbf{v}) - \kappa B(\hat{\mathbf{y}}, \mathbf{v})\}. \quad (3.130)$$

监督基线 $\hat{\mathbf{y}} = \mathbf{y}^0$ 总能给出零净收益，所以这一离散问题的最优值至少为零。若真实标签向量 $\mathbf{y}^*$ 确实属于 $\mathbf{V}$ ，并且最终输出对所有候选的净收益都非负，那么

$$G(\hat{\mathbf{y}}, \mathbf{y}^*) - B(\hat{\mathbf{y}}, \mathbf{y}^*) \geq G(\hat{\mathbf{y}}, \mathbf{y}^*) - \kappa B(\hat{\mathbf{y}}, \mathbf{y}^*) \geq 0.$$

左侧正是相对于基线新增的正确预测数，因而在当前 U 上准确率不会降低。这一推理同时给出了保证的边界：真实标签不在候选集中时，最坏情形比较没有覆盖实际情形；即使覆盖成立，结论也针对这批输入，而不是未来样本上的任意分布风险。

S4VM 通过不同的候选搜索策略近似探索这些划分，包括模拟退火或代表性采样。连续松弛和取整后的输出还需检查相对于候选集的净收益条件，不满足时可以回退到监督基线。候选覆盖无法仅凭无标签输入验证，扩大搜索也不自动证明已经覆盖真实划分。因此，S4VM 提供的是一种明确管理半监督不确定性的思路，仍需要对候选构造、数值求解与应用分布分别负责。

回到本节开头的问题，未标注输入能够补充的是分布与结构信息，而不是额外的真实答案。置信度筛选、图上平滑、低密度分离和生成式 EM 分别把这些信息转成伪标签、平滑约束、间隔偏好或潜类别统计量；协同训练、软传播、流形正则化与安全选择又改变了监督来源、约束强度或损害控制方式。选择方法时，应检查这些联系在任务中是否可信，用保留的真实标签比较收益，并把预测质量与求解是否收敛分别报告。这样才能判断未标注数据究竟补上了什么信息，以及何时应当保留纯监督结果。

⁸⁸ Y.-F. Li, Z.-H. Zhou, *Towards Making Unlabeled Data Never Hurt* In Proceedings of the 28th International Conference on Machine Learning, 2011, pp. 1081–1088

3.7 模型选择与评价

3.7.1 方法比较

表3.6比较分类器怎样形成类别判断、利用训练信息和解释输出。类别得分、硬标签与类别概率承担不同职责；一个分类器也可能同时使用线性关系、概率模型或集成。

代表方法	输出语义	决策依据	训练信息	概率或校准	标签条件
LDA、感知机、SVM	类别得分与硬标签	投影、错误反馈或分类间隔	类统计量、错分样本或支持向量	LDA 可有生成式后验；其余得分需另行校准	完整监督
k-NN、LVQ、最近质心	硬标签；投票比例或距离得分	局部邻居或类别原型	保存带标签样本，或从标签学习原型	投票比例可作局部概率估计，准确性与校准仍需检验；距离得分须另建概率映射	完整监督
ID3、C4.5、CART、RIPPER	硬标签；叶频率或规则得分可作辅助量	条件分支、规则覆盖与默认类	完整标签下搜索结构并控制复杂度	经验频率不自动校准	完整监督
Logistic 回归、NB、GDA	类别概率与硬标签	条件后验或类条件似然	带标签样本的条件似然或联合似然	原生概率仍须样本外检验校准	完整监督
Bagging、随机森林、AdaBoost、GBDT、Stacking	聚合得分、投票或概率	并行平均、序贯修正或元学习组合	重采样、加权轮次、伪残差或折外预测	概率平均和元模型输出仍须校准	通常为完整监督
Self-Training、Label Propagation、TSVM、生成式 EM	硬标签、类别得分或后验	伪标签、图平滑、低密度分离或联合模型	少量标签与未标注输入共同参与	取决于基分类器或生成模型，均须检验	半监督

表 3.6 经典分类方法的属性导航。各行按本章顺序比较输出、决策、训练信息、概率语义与标签条件；具体变体可以改变其中的设定。

3.7.2 评价与选择

模型比较还要先确定交付接口。硬标签、排序分数、概率、类别不平衡、误判代价和资源预算分别对应不同证据，不能都压缩成一个总体正确率。表3.7把训练证据、选择证据、需要时的校准证据和测试证据分开：训练目标说明算法在拟合什么，验证数据用于选择模型、超参数和阈值；只有后处理概率或相应程序明确需要时，才另用未参与拟合与选择的数据校准；最终测试则在这些决定冻结后评价部署所需结果。对于本章的有限多分类任务，精确率、召回率、ROC 和 PR 都要先声明目标类别，并把该类与其余类别作一对其余比较；需要总体汇总时，再同时说明逐类结果以及宏观或微观口径。准确率或 AUROC 都不能替代全部目标：前者会掩盖类别条

件错误与代价，后者评价跨阈值排序，不能给出部署阈值处的错误、概率质量或资源消耗。

评价接口	训练证据	选择证据	校准证据（需要时）	测试证据
硬标签	零一损失的代理目标或代价敏感目标	验证混淆矩阵、逐类错误和任务损失	不适用；若改变阈值则转到得分接口	冻结规则后的准确率、逐类精确率/召回率/ F_1 及宏观、微观汇总
排序分数	间隔、成对排序或其他得分损失	对目标类别验证一对其余 ROC/PR 曲线与工作区，选定阈值	若要解释为概率，另拟合并验证单调映射	逐类及宏观/微观 AUROC 或 AUPRC，加部署阈值处的混淆矩阵与代价
类别概率	条件似然、对数损失、Brier 分数等适当目标	验证适当评分、区分能力和概率诊断	后处理校准器使用独立留出或折外预测	测试对数损失、Brier 分数、可靠性图及决策损失
类别不平衡	训练折内使用重加权、重采样或类别敏感损失	按目标类别检查一对其余召回率、精确率、PR 区域和阈值稳定性	概率使用时按重要类别或群体检查偏差	报告类别支持量、逐类错误及宏观、微观汇总，不能只报准确率
误判代价	用预先给定的代价矩阵定义训练或决策目标	在验证集上选择阈值和行动规则	概率决策依赖校准时单独检验	在固定代价和基线下报告总损失、主要代价项或关键错误对
资源预算	记录训练时间、峰值内存和搜索预算	在相同调参预算下筛除不可部署候选	计入额外校准数据与计算	报告延迟、吞吐、模型大小及完整训练成本

表 3.7 分类模型的统一评价协议。不同接口回答不同问题；选择和校准结束后才使用最终测试集，报告单一汇总指标不能替代类别、代价、概率和资源证据。

混淆矩阵、精确率、召回率和阈值选择的基础见第二卷“基础、理论和可信性”的“引言”章“性能度量”节；用于多分类时，应同时记录目标类别的一对其余定义与宏观、微观聚合方式。概率向量的可靠性图、Brier 分数和适当评分见第二卷“基础、理论和可信性”的“可靠性”章“概率与预测范围的检验”小节。章首邮件任务可据此固定训练、验证、必要的校准和测试数据：先在训练折内完成特征处理与拟合，再用验证结果选择模型及阈值；若需要把 SVM 等排序分数转换为概率，则只用留出数据或折外预测拟合校准器；最后在独立测试集上同时报告误拦、漏放、概率质量和延迟。看过测试结果后继续选模型或阈值，该批数据就不再是独立测试证据。

统一选型应先确定输出语义：只交付硬标签、需要可移动阈值的排序分数，还是需要支持代价决策的类别概率。随后根据类别不平衡与误判代价固定验证指标和阈值规则，再比较数据几何、样本量及可接受的模型假设；最后在相同训练、调参和资源预算下比较候选方法。对于文本或日志等高维稀疏输入，可以从 Logistic 回归、线性 SVM 与多项式朴素贝叶斯建立基线。需要审阅逐条判断时，小型决策树或规则列表更便于检查；需要连续的风险评分时，概率模型更容易接入阈值决策，但仍须用独立数据检验校准。中小规模数据中，核 SVM 与近邻方法提供不同的非线性建模途径；当低维连续特征的高斯近似合理时，GDA 可以利用协方差信息。

标签稀缺时，自训练需要可靠伪标签，标签传播需要可信邻接关系，TSVM 需要低密度区域与类别边界相符。未标注样本多并不能保证收益，应以保留的真实标签比较这些方法与纯监督基线。

3.8 本章小结

分类从已知类别学习决策。线性与核模型学习类别得分，邻域方法聚合局部标签，树与规则形成条件判断，概率方法估计后验，集成组合预测；半监督方法进一步利用未标注输入，但其收益依赖额外的结构假设。

类别得分、硬标签和概率承担不同职责。比较模型时，需要按交付目标固定错误指标、阈值与误判代价，再检查概率质量和资源成本。求解收敛、统计泛化与概率校准不能互相代替：训练目标达到要求，并不直接保证新样本风险或概率可信。

第4章撤去预设类别，讨论怎样从输入定义并验证群组。局部邻域、质心和概率分布仍会使用，但它们要服务于发现结构，而非复现给定标签。

聚类

没有客户类别标签时，可以按消费行为寻找相近人群，但“相近”可能指金额、品类或购买频率。**聚类**（clustering）依据选定的相似性与结构假设发现群组，簇的定义也由此成为建模选择。给定 $\mathbf{x}_1, \dots, \mathbf{x}_n \in \mathbb{R}^d$ ，硬划分记为 $\mathcal{P} = \{C_1, \dots, C_K\}$ ， C_k 为簇的样本索引集合， $c_i = k$ 表示 $i \in C_k$ ；通常要求各簇非空、互斥并覆盖样本，允许噪声、重叠或软归属时另行说明。

1950 至 1960 年代，中心划分与层次聚类逐渐形成，K-means 成为代表方法。1990 年代的数据挖掘推动了 DBSCAN 等密度方法及大规模、子空间聚类；谱方法则从图关系理解群组。概率混合思想有更早的统计来源，19 世纪末已用于分析异质总体¹。

现在，K-means 及其小批量变体仍常用于大样本分组与量化；需要保留非凸形状和噪声时，可以考虑 DBSCAN 或 HDBSCAN；需要多层粒度或软归属时，则分别考虑层次方法或混合模型。选择取决于所需结构，不能只按某种方法是否流行决定²。

本章从原型出发，依次讨论邻域、图、网格与子空间、层次、概率和集成，随后加入半监督约束。原型代表一组样本，邻域与图利用连接，网格与子空间寻找局部相关结构，层次保留嵌套分组，概率解释成分归属，集成汇总不同分组；这些思路承接第1章，也可以组合使用。

4.1 基于原型的聚类

如果希望把客户明确分成 K 组，最直接的办法是为每组选择一个代表，再使组内样本尽量接近这个代表。本节的原型聚类把这一要求写成簇内相异度之和的最小化。簇间分离通常由竞争性的分配规则间接产生，目标中未必另含一个“簇间距离最大”的项。

K-means 用均值表示簇，计算方便；K-medoids 用真实样本表示簇，能够使用更一般的相异度。两者共享分配与代表选择的思路，但优化变量和求解方法不同。

¹ J. MacQueen, *Some Methods for Classification and Analysis of Multivariate Observations* In Proceedings of the Fifth Berkeley Symposium on Mathematical Statistics and Probability, 1967, pp. 281–297; M. Ester, H.-P. Kriegel, J. Sander, X. Xu, *A Density-Based Algorithm for Discovering Clusters in Large Spatial Databases with Noise* In Proceedings of the Second International Conference on Knowledge Discovery and Data Mining, 1996, pp. 226–231; K. Pearson, *Contributions to the Mathematical Theory of Evolution* In Philosophical Transactions of the Royal Society of London. A, 1894, vol. 185, pp. 71–110

² scikit-learn developers, *Clustering*, scikit-learn User Guide, URL: <https://scikit-learn.org/stable/modules/clustering.html> (visited on 10/04/2026)

4.1.1 K-means

若样本是数值向量，均值是一个自然的代表：它综合了簇内所有样本的位置。**K均值聚类**（K-means）据此寻找 K 个中心，使样本到所属中心的平方距离之和尽量小。

K-means 并非在一篇论文中一次成形。Steinhaus 的早期论文《论物质的分割》载于该刊第 4 卷第 12 期；卷册标为 1956 年，zbMATH 则按 1957 年著录³。MacQueen 在 1967 年讨论多元观测的分类与分析时使用了 K-means 这一名称，并给出逐个吸收样本、随即调整均值的增量方法⁴。因此，文献中的“K-means”既可能指平方误差聚类目标，也可能指某种具体更新算法，阅读时需要区分。

本节采用的批量算法来自 Lloyd 对信号量化的研究：把连续幅值映射为有限个代表值，同样需要最小化平方失真。相关工作完成于 1957 年，经典论文直到 1982 年才正式发表⁵。它把“选择最近代表”和“重新计算代表”交替执行，与 MacQueen 的逐样本更新不同。今天常见的批量 K-means 实现主要沿用这一 Lloyd 过程。

K-means 的吸引力在于目标和计算彼此配合：一轮分配与更新只需 $O(nKd)$ 运算。它既可独立用于用户分群、向量量化和图像颜色压缩，也可作为谱聚类或混合模型提供基础步骤。

4.1.1.1 模型结构

为第 k 个簇配置中心 $\mu_k \in \mathbb{R}^d$ ，其**簇内平方误差**（sum of squared errors, SSE）为

$$J(\mathcal{P}, \mu) = \sum_{k=1}^K \sum_{i \in C_k} \|x_i - \mu_k\|_2^2. \quad (4.1)$$

这里 $\mu = (\mu_1, \dots, \mu_K)$ 表示中心参数。固定中心后，每个样本应归入距离最近的中心；固定分配后，每个中心应取簇内均值。

平方欧氏距离使同一中心的等距离面成为球面，最近中心的分配区域则是由超平面分隔的 Voronoi 单元。因此 K-means 偏好紧凑、尺度相近的簇，不能自然恢复环形等非凸结构。这是一种几何偏好，并不要求每个实际簇都严格服从球形高斯分布。

³ H. Steinhaus, *Sur la division des corps matériels en parties* In Bulletin de l'Académie Polonaise des Sciences, Classe III, 1957, vol. 4, no. 12, pp. 801–804

⁴ J. MacQueen, *Some Methods for Classification and Analysis of Multivariate Observations* In Proceedings of the Fifth Berkeley Symposium on Mathematical Statistics and Probability, 1967, pp. 281–297

⁵ S. P. Lloyd, *Least Squares Quantization in PCM* In IEEE Transactions on Information Theory, 1982, vol. 28, no. 2, pp. 129–137

4.1.1.2 参数学习

同时优化中心和分配较难，但两个条件子问题都可直接求解。记第 t 轮的分配为 $c_i^{(t)}$ ，Lloyd 更新写为

$$c_i^{(t+1)} \in \arg \min_{1 \leq k \leq K} \|x_i - \mu_k^{(t)}\|_2^2, \quad (4.2)$$

$$\mu_k^{(t+1)} = \frac{1}{|C_k^{(t+1)}|} \sum_{i \in C_k^{(t+1)}} x_i. \quad (4.3)$$

图 4.1 把两步更新放在同一组样本上。中图只移动中心，簇分配仍保持左图的状态；到右图重新比较距离时，样本 (1,0) 才从方块簇转入圆点簇。目标值的降低因此来自两个不同动作，不能把中心一移动就立即重画所有簇标记当作同一个更新步。




图 4.1 Lloyd 迭代的教学例，六个样本为 (0,0)、(0,1)、(1,0)、(4,2)、(4,3)、(5,2)，初始中心为 (0,0) 和 (1,0)。圆点与方块表示两个簇，十字表示中心，虚线表示等距边界。首次更新后中心为 (0,0.5) 和 (3.5,1.75)；图中依次展示分配、均值更新与再次分配。

为避免等距离样本反复换簇，若原簇分配仍为最优分配，就保留原分配；初始化时按固定顺序打破平局。空簇没有均值，必须另作约定。下面的教学实现保留空簇的旧中心，因此最多输出 K 个非空簇；若应用要求恰好 K 个非空簇，可以重启或采用后文的容量约束。

代码 4.1 带平局与空簇处理的 Lloyd 迭代

```
1 import numpy as np
2
3 def kmeans(X, K, max_iter=300, seed=0):
4     X = np.asarray(X, dtype=float)
5     n = len(X)
6     if not 1 <= K <= n or max_iter < 1:
7         raise ValueError("invalid K or max_iter")
8     rng = np.random.default_rng(seed)
```

```

9     mu = X[rng.choice(n, K, replace=False)].copy()
10    labels = np.full(n, -1)
11    for _ in range(max_iter):
12        d2 = ((X[:, None] - mu[None]) ** 2).sum(2)
13        new = d2.argmin(1)
14        rows = np.flatnonzero(labels >= 0)
15        keep = d2[rows, labels[rows]] == d2[rows, new[rows]]
16        new[rows[keep]] = labels[rows[keep]]
17        if np.array_equal(new, labels):
18            return labels, mu
19        labels = new
20        for k in range(K):
21            members = X[labels == k]
22            if len(members):
23                mu[k] = members.mean(0)
24    return labels, mu

```

代码假定输入是有限的二维数值数组。达到迭代上限时，返回的中心是返回分配的均值，但分配未必已是这些中心的最近中心分配；使用者应区分“达到上限”和“到达不动点”。广播距离的实现还会临时占用 $O(nKd)$ 空间，大数据实现通常分块计算。

初始化决定算法从哪个局部区域开始搜索。**K-means++** 以距离加权采样选择初始中心：先均匀选择一个样本，随后按 $D_i^2 / \sum_j D_j^2$ 选择新中心，其中 D_i 是 $\mathbf{x}_i$ 到已有中心的最短距离。若所有 $D_i = 0$ ，已有中心已经覆盖全部不同位置。Arthur 与 Vassilvitskii 证明，其初始目标值满足 $\mathbb{E}[J] \leq 8(\log K + 2)J^*$ ；后续 Lloyd 更新不会破坏这一期望上界⁶。

这一保证针对平方距离目标的期望近似质量，不表示单次运行一定接近最优。标准 K-means++ 需要逐个增加中心，代价约为 $O(nKd)$ ；它通常值得采用，但在分布式环境下仍需考虑扫描和通信。

⁶ D. Arthur, S. Vassilvitskii, *k-means++: The Advantages of Careful Seeding* In Proceedings of the Eighteenth Annual ACM-SIAM Symposium on Discrete Algorithms, 2007, pp. 1027–1035

4.1.1.3 理论分析

收敛性分析 Lloyd 算法为何会停止，需要同时解释目标下降和平局处理。仅说“目标有下界”只能证明目标值收敛，不能推出有限停止。

定理 4.1 Lloyd 算法的单调性与有限停止 对有限样本，在精确计算下，分配步采用最近中心规则，并在平局时优先保留原簇分配；更新步对非空簇取均值、对空簇保留旧中心。则目标值单调不增，算法在有限轮后到达分配和中心均不再变化的不动点。

证明. 固定中心, 逐点选择最小距离给出

$$J(\mathcal{P}^{(t+1)}, \boldsymbol{\mu}^{(t)}) \leq J(\mathcal{P}^{(t)}, \boldsymbol{\mu}^{(t)}).$$

对任意非空簇 C , 记均值为 $\bar{\mathbf{x}}_C$. 展开平方项, 并利用 $\sum_{i \in C} (\mathbf{x}_i - \bar{\mathbf{x}}_C) = \mathbf{0}$, 得到

$$\sum_{i \in C} \|\mathbf{x}_i - \mathbf{a}\|_2^2 = \sum_{i \in C} \|\mathbf{x}_i - \bar{\mathbf{x}}_C\|_2^2 + |C| \|\mathbf{a} - \bar{\mathbf{x}}_C\|_2^2. \quad (4.4)$$

所以均值是唯一最优中心, 更新步也不会增加目标; 空簇对目标贡献为零。

第一次均值更新后, 若分配改变, 至少一个样本移向严格更近的中心, 否则保留原标签的规则会阻止改变。因此完整一轮使目标严格下降。对任一分配, 均值更新后的目标只由该分配决定, 即使存在空簇也如此。分配至多有 K^n 种, 严格下降不可能无限次访问它们。分配不变时, 已有非空簇中心仍为相同均值, 算法遂停止。 ■

不动点是分块优化意义下的解, 不能无条件称为严格局部极小值; 等距离、重合中心等退化情况尤其需要区分。若所有样本的最近中心唯一且各簇非空, 则在足够小的中心扰动下分配不变, 均值最优性才给出相应的局部最优解释。

全局求解仍然困难。当维数是输入的一部分时, Aloise 等证明了即使固定 $K = 2$, 欧氏平方和聚类仍为 NP-hard⁷。在平面上把 K 作为输入时, Mahajan、Nimbhorkar 与 Varadarajan 也得到了 NP-hard 结果⁸。因此, 除非 $P = NP$, 不能期待一般输入都有多项式时间的精确算法。

泛化分析 训练 SSE 的下降也不等于统计泛化。若未来样本 $\mathbf{X}$ 与训练样本同分布, 可考察总体量化误差 $\mathbb{E}[\min_k \|\mathbf{X} - \boldsymbol{\mu}_k\|_2^2]$; 经验全局最优中心在矩条件和适当唯一性条件下有一致性理论, 但这种结论不能直接套到任意一次 Lloyd 运行上⁹。

实际误差还取决于表示方式。平方距离会放大离群样本的影响, 不同量纲会改变最近中心关系; 标准化应结合业务含义, 而非机械处理每一维。距离和尺度同样决定第2.2.1节的 k -NN 回归会选中哪些邻居; 两者都依赖输入几何, 但 K-means 优化无标签样本的量化误差, k -NN 回归则聚合带响应的邻域样本。多次重启可以改善优化结果, 改变相似度或模型才可能纠正结构假设的失配。

4.1.1.4 支持大规模数据 (Mini-Batch K-means)

全量扫描在大数据上代价较高。Sculley 在 2010 年提出**小批量 k 均值聚类** (Mini-Batch K-means) 来降低更新成本¹⁰。算法每轮抽取 b 个样本, 只更新它们涉及的中心。

⁷ D. Aloise, A. Deshpande, P. Hansen, P. Popat, *NP-Hardness of Euclidean Sum-of-Squares Clustering* In Machine Learning, 2009, vol. 75, no. 2, pp. 245–248

⁸ M. Mahajan, P. Nimbhorkar, K. Varadarajan, *The Planar k -Means Problem Is NP-Hard* In Theoretical Computer Science, 2012, vol. 442, pp. 13–21

⁹ D. Pollard, *Strong Consistency of k -Means Clustering* In The Annals of Statistics, 1981, vol. 9, no. 1, pp. 135–140

¹⁰ D. Sculley, *Web-Scale k -Means Clustering* In Proceedings of the 19th International Conference on World Wide Web, 2010, pp. 1177–1178

设簇 k 累计接收了 v_k 次样本更新。每接收一个分配到该簇的样本，就令 $v_k \leftarrow v_k + 1$ ，并计算

$$\mu_k \leftarrow (1 - \eta_k)\mu_k + \eta_k \mathbf{x}_i, \quad \eta_k = \frac{1}{v_k}. \quad (4.5)$$

这是对历史已分配样本的增量平均，不是当前全体簇成员的精确均值。一轮距离计算降为 $O(bKd)$ ，但总成本仍取决于迭代次数、初始化和最终全量分配。

小批量更新会引入随机波动，不能沿用定理 4.1 的逐轮 SSE 单调性。批量大小、采样偏差和低频簇的覆盖都会影响质量；它以可控的近似误差换取吞吐量，是否足够准确应通过抽样评估或留出数据上的量化误差判断。

4.1.1.5 支持限制簇大小 (Constrained K-means)

最小 SSE 不一定满足容量需求。客户分区、任务分片或服务网点分配常要求每簇至少或至多容纳一定数量的样本。Bradley、Bennett 与 Demiriz 研究了带最小簇规模的 K-means；加入上界后，固定中心的分配问题可统一写为¹¹。

$$\begin{aligned} \min_{\mathbf{Z}} \quad & \sum_{i=1}^n \sum_{k=1}^K z_{i,k} \|\mathbf{x}_i - \mu_k\|_2^2, \\ \text{s.t.} \quad & \sum_{k=1}^K z_{i,k} = 1, \quad z_{i,k} \in \{0, 1\}, \\ & \ell_k \leq \sum_{i=1}^n z_{i,k} \leq u_k. \end{aligned} \quad (4.6)$$

¹¹ P. S. Bradley, K. P. Bennett, A. Demiriz, *Constrained K-Means Clustering*, tech. rep. MSR-TR-2000-65, Microsoft Research, 2000

整数容量满足 $0 \leq \ell_k \leq u_k$ ，且在没有其他分配禁令时，可行性条件为 $\sum_k \ell_k \leq n \leq \sum_k u_k$ 。

这个子问题可用最小费用流精确求解：源点向每个样本连容量为 1 的边，每个样本向每个簇连容量为 1、费用为平方距离的边，每个簇向汇点连下界为 ℓ_k 、上界为 u_k 的边，并要求总流量为 n 。整数容量的网络流存在整数最优解，故每个样本恰好选中一簇。这里的关键是网络结构的整数性，而不只是线性规划属于凸优化。

更新步仍取均值。若每次分配精确最优，且平局时保留已有最优分配，则每次发生改变都会降低目标；配合确定的空簇处理，可沿用有限分配的停止论证。分配成本取决于网络规模、费用表示和求解器，不能统一写成一个不附条件的固定幂次。

Malinen 与 Fränti 在 2014 年研究了要求簇规模相等的平衡 K-means¹²。当 K 整除 n 且要求 $|C_k| = n/K$ 时，把每个中心复制成相应数量的容量槽，得到 n 对 n 的指派问题；Hungarian 算法可在 $O(n^3)$ 时间内求解。

若 n 不能被 K 整除，可指定各簇容量为 $\lfloor n/K \rfloor$ 或 $\lceil n/K \rceil$ ，并使总和为

¹² M. I. Malinen, P. Fränti, *Balanced K-Means for Clustering In Structural, Syntactic, and Statistical Pattern Recognition*, 2014, pp. 32–41

n 。按距离依次填满簇的启发式更便宜，但会受处理顺序影响，也未必满足所有下界或降低 SSE。

4.1.1.6 小结

K-means 适合数值表示可靠、簇较紧凑且需要快速硬划分的任务。其计算优势来自平方距离和均值更新，代价是对尺度、离群点、初始化及 K 的选择敏感。Mini-Batch 主要改变计算方式，容量约束主要改变可行域；二者都没有自动消除原有几何假设。

4.1.2 K-medoids

如果要展示一个真实客户作为群组代表，均值记录可能没有业务意义；对字符串等对象，均值甚至没有定义。**K 中心样本聚类** (K-medoids) 要求代表本身来自样本集，因而只需定义对象间相异度。

Kaufman 与 Rousseeuw 在 1987 年以“通过 medoid 聚类”为题介绍了这一方法¹³。用观测对象而非虚构均值表示簇，使相异度矩阵可以直接成为输入。两人在 1990 年的专著中进一步系统整理了 PAM、面向较大数据的 CLARA，以及相邻的层次分析方法¹⁴。这一发展过程把两个问题分开了：如何定义一个有解释性的代表，以及如何在大量候选代表中有效搜索。

4.1.2.1 模型结构

设代表索引集合 $M = \{m_1, \dots, m_K\} \subseteq \{1, \dots, n\}$ ，相异度为 $\delta(\mathbf{x}, \mathbf{y})$ 。优化目标为

$$J(M) = \sum_{i=1}^n \min_{m \in M} \delta(\mathbf{x}_i, \mathbf{x}_m). \quad (4.7)$$

每个 $\mathbf{x}_{m_k}$ 称为**中心样本** (medoid)，分配由最近代表决定。典型相异度包括欧氏距离、曼哈顿距离、汉明距离、编辑距离和 Jaccard 距离。目标本身不要求三角不等式，但某些索引加速方法需要这一性质。

使用未平方的距离可以降低远处样本相对于 SSE 的影响，而中心被限制为真实样本也阻止均值式的连续偏移。不过鲁棒性仍取决于距离和污染结构，不能仅因采用 medoid 就认为结果不受离群点影响。

图 4.2 用一维、单簇情形隔离这种差别。把最右侧样本从 5 移到 12 后，平方距离的最优中心随均值右移，而绝对距离的最优中心样本仍为中间观测 2。这个例子同时改变了代表约束与损失形式，说明的是这组设定下的稳健性差异。

¹³ L. Kaufman, P. J. Rousseeuw, *Clustering by Means of Medoids In Statistical Data Analysis Based on the L1-Norm and Related Methods*, 1987, pp. 405–416

¹⁴ L. Kaufman, P. J. Rousseeuw, *Finding Groups in Data: An Introduction to Cluster Analysis*, Wiley, 1990, 1st ed.




图 4.2 中心样本与均值对极端值的不同反应。固定 $K = 1$, 上方样本为 $\{0, 1, 2, 3, 5\}$, 下方只把 5 改为 12; 黑点为观测, 圆圈标出绝对距离下的 medoid, 三角形标出平方距离下的最优均值。

4.1.2.2 参数学习

围绕中心样本划分 (Partitioning Around Medoids, PAM) 通常包含 BUILD 初始化和 SWAP 改进。BUILD 贪心增加代表; SWAP 枚举每个当前代表 $m \in M$ 与每个非代表 $o \notin M$, 计算

$$\Delta(m, o) = J((M \setminus \{m\}) \cup \{o\}) - J(M).$$

候选 o 来自整个数据集, 而限于 m 所在簇; 每次交换后, 所有样本都重新选择最近代表。只在固定簇内选取距离总和最小的样本, 是另一种交替更新, 不能替代 PAM 的 SWAP。

下面代码从随机代表开始, 实现完整的交换邻域搜索, 便于核对目标定义; 它没有实现 BUILD, 也没有缓存距离差分, 因此主要用于教学。

代码 4.2 PAM 的完整交换步骤

```
1 import numpy as np
2
3 def pam_swap(D, K, seed=0, max_iter=100):
4     n = len(D)
5     if D.shape != (n, n) or not 1 <= K <= n or max_iter <
6         1:
7         raise ValueError("invalid distance matrix, K, or
8             max_iter")
9     rng = np.random.default_rng(seed)
10    medoids = rng.choice(n, K, replace=False)
11    cost = D[:, medoids].min(1).sum()
12    converged = False
13    for _ in range(max_iter):
14        best, best_cost = None, cost
```

```

13     outside = np.setdiff1d(np.arange(n), medoids)
14     for k in range(K):
15         for o in outside:
16             trial = medoids.copy()
17             trial[k] = o
18             value = D[:, trial].min(1).sum()
19             if value < best_cost:
20                 best, best_cost = trial, value
21     if best is None:
22         converged = True
23     break
24     medoids, cost = best, best_cost
25     return D[:, medoids].argmin(1), medoids, converged

```

严格改进的交换不可能重复同一个代表集合。若某轮完整扫描没有找到改进交换，代码令 `converged=True`，此时返回的代表集合才是单次交换邻域中的局部最优；若 `max_iter` 用尽，返回的 `converged=False` 表示不能确认这一性质，当前集合仍可能存在改进交换。去掉迭代上限并持续完整扫描时，有限个代表集合才能保证过程最终在这样的局部最优处停止。预计算相异度矩阵需要 $O(n^2)$ 存储；若距离计算本身昂贵，还须计入其成本。经典 PAM 利用最近和次近代表缓存，一轮完整交换搜索通常按 $O(K(n-K)^2)$ 量级分析；上面朴素代码每个候选都重算 K 个距离列，成本更高。

CLARA 在若干子样本上运行 PAM，再用全体样本评价候选代表，适合控制内存，但可能漏掉小簇。CLARANS 把代表集合视为搜索状态，随机抽取交换邻居，减少完整邻域扫描¹⁵。

FastPAM 通过复用不同被替换代表之间的计算，减少经典交换步骤中对 K 的重复工作；主要加速约为一个 K 因子，而不是把整个算法变为对 n 线性。全量距离矩阵仍可能成为瓶颈¹⁶。

4.1.2.3 小结

K-medoids 适合需要真实代表、非数值对象或一般相异度的场景。相对于平方距离的 K-means，它常能减轻极端值的影响，但交换搜索和距离矩阵增加了成本。是否采用 CLARA、CLARANS 或 FastPAM，应根据允许的近似误差和距离存储预算决定。

4.1.3 模型对比与总结

本小节先比较 K-means 与 K-medoids，再把改变中心、输出粒度或表示方式的方法作为代表性扩展。K-means 和 K-medoids 的区别不只是中心的名

¹⁵ R. T. Ng, J. Han, *Efficient and Effective Clustering Methods for Spatial Data Mining* In Proceedings of the 20th International Conference on Very Large Data Bases, 1994, pp. 144–155

¹⁶ E. Schubert, P. J. Rousseeuw, *Faster k-Medoids Clustering: Improving the PAM, CLARA, and CLARANS Algorithms* In Similarity Search and Applications, 2019, pp. 171–187

称：前者允许中心在向量空间中移动，并优化平方欧氏距离；后者在有限样本集合中选择代表，可以使用更一般的相异度。二者不是彼此在同一约束下的特殊情况。表 4.1 给出了直接比较。

比较项	K-means	K-medoids
代表	簇内均值向量	真实样本
准则	平方欧氏距离和	指定相异度和
优化步骤	最近中心与均值更新	代表交换与全局重分配
主要成本	一轮 $O(nKd)$	完整交换搜索与距离访问
典型用途	数值数据、向量量化	非数值对象、实例解释

表 4.1 两类划分方法的比较。复杂度须与具体算法相联系；PAM 的成本不能套到所有 K-medoids 求解器。

沿中心与相异度两个方向，可以得到其他划分模型。**K 中位数聚类** (K-medians) 最小化 ℓ_1 距离和，固定分配后逐坐标取中位数；它不等于以欧氏距离和定义的几何中位数问题。

若簇之间允许模糊重叠，**模糊 C 均值** (Fuzzy C-Means, FCM) 用隶属度 $u_{i,k}$ 代替硬簇分配¹⁷。

$$J_{\text{FCM}} = \sum_{i=1}^n \sum_{k=1}^K u_{i,k}^q \|\mathbf{x}_i - \boldsymbol{\mu}_k\|_2^2, \quad \sum_k u_{i,k} = 1, \quad q > 1. \quad (4.8)$$

这里 q 是模糊指数。固定隶属度时，中心是以 $u_{i,k}^q$ 为权重的均值；当各距离非零时，固定中心给出

$$u_{i,k} = \left[\sum_{j=1}^K \left(\frac{\|\mathbf{x}_i - \boldsymbol{\mu}_k\|_2}{\|\mathbf{x}_i - \boldsymbol{\mu}_j\|_2} \right)^{2/(q-1)} \right]^{-1}.$$

若样本与一个或多个中心重合，可把隶属度集中在这些零距离中心上。隶属度表达目标函数意义下的软归属，并不自动等于生成模型的后验概率；医学影像中的部分体积效应是这类软表达的一个应用动机。

另一种改动针对分裂顺序。**二分 K-means** (Bisecting K-means) 从全部样本属于一个簇开始，反复选择一个簇运行 $K = 2$ 的 K-means，直到得到所需簇数。选择最大 SSE 的簇并对每次二分多次重启，是一种常见做法；它形成层次树，但早期分裂也会限制后续结果，不能保证总比一次性 K 分更优。Steinbach 等在文档聚类比较中研究了这一方案¹⁸。

¹⁷ J. C. Bezdek, *Pattern Recognition with Fuzzy Objective Function Algorithms*, Plenum Press, 1981, 1st ed.

¹⁸ M. Steinbach, G. Karypis, V. Kumar, *A Comparison of Document Clustering Techniques*, tech. rep. 00-034, University of Minnesota, 2000

若主要困难是原空间中的非凸形状, 可在特征映射 ϕ 后运行核 K-means (kernel K-means)。使用第1.2.1.1节定义的正定核 K , 本节只需把簇内平方距离改为特征空间距离。样本到簇均值的平方距离为

$$\begin{aligned} \|\phi(\mathbf{x}_i) - \mu_k^\phi\|^2 &= K(\mathbf{x}_i, \mathbf{x}_i) - \frac{2}{|C_k|} \sum_{j \in C_k} K(\mathbf{x}_i, \mathbf{x}_j) \\ &\quad + \frac{1}{|C_k|^2} \sum_{j, l \in C_k} K(\mathbf{x}_j, \mathbf{x}_l). \end{aligned} \quad (4.9)$$

所以不必显式计算 ϕ , 但要承担核矩阵的计算和存储¹⁹。Girolami 讨论了核空间聚类; Dhillon、Guan 与 Kulis 进一步建立了带适当权重和核构造的核 K-means 与归一化割之间的联系。

这个等价关系有具体的权重与核条件, 不能理解成任意普通核 K-means 都等于任意归一化割。它也说明, 原空间中偏好凸形区域的性质不应推广到所有划分方法。若希望保留多种粒度, 第4.5节的层次结构提供另一种输出形式; 下面先考察邻域中的局部密度与连接。

4.2 基于邻域的聚类

对于环形、月牙形或弯曲条带, 单个中心未必能代表整个簇, 但沿着样本密集处行走, 仍可能从簇的一端到达另一端。基于密度的聚类据此寻找由低密度区域分隔的结构。这里有两种不同的定义: 一种把簇看成密集区域的连通分量, 另一种把簇看成密度峰的吸引域。二者都不要求球形簇, 却未必产生相同结果。

DBSCAN 直接用邻域计数判断密集程度, OPTICS 保留不同密度尺度的访问结构, Mean Shift 则沿核密度估计寻找驻点。噪声识别是前两者的显式输出; 基本 Mean Shift 会为起点寻找归宿, 并不自动拒绝孤立样本。

4.2.1 DBSCAN

DBSCAN (Density-Based Spatial Clustering of Applications with Noise) 用“周围是否有足够多邻居”判断一个样本能否继续扩展簇。Ester 等在 1996 年提出这一方法, 使任意形状的密集连通区域和噪声能够在同一流程中处理²⁰。

原始 DBSCAN 工作面向带噪声的大型空间数据库, 明确把发现任意形状的簇、减少领域参数知识的要求和提高大数据处理效率列为设计目标。由此形成的关键选择, 是通过邻域计数与连通扩展寻找区域, 而不是先指定若干中心, 再强制每个样本归属其中之一。这也解释了噪声标记为何是模型定义的一部分。

¹⁹ M. Girolami, *Mercer Kernel-Based Clustering in Feature Space* In IEEE Transactions on Neural Networks, 2002, vol. 13, no. 3, pp. 780–784; I. S. Dhillon, Y. Guan, B. Kulis, *Kernel k-Means, Spectral Clustering and Normalized Cuts* In Proceedings of the Tenth ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 2004, pp. 551–556

²⁰ M. Ester, H.-P. Kriegel, J. Sander, X. Xu, *A Density-Based Algorithm for Discovering Clusters in Large Spatial Databases with Noise* In Proceedings of the Second International Conference on Knowledge Discovery and Data Mining, 1996, pp. 226–231

4.2.1.1 模型结构

固定半径 $\varepsilon > 0$ 和最小邻域样本数 $m = \text{MinPts}$ ，定义索引邻域

$$N_\varepsilon(i) = \{j : \delta(\mathbf{x}_i, \mathbf{x}_j) \leq \varepsilon\}.$$

本节假定相异度对称、样本到自身距离为零，并在邻域计数中包含自身。

核心点 (core point) 满足 $|N_\varepsilon(i)| \geq m$ ；**边界点** (border point) 不是核心点，但处在某个核心点的邻域内；既非核心也非边界的样本是**噪声点** (noise point)。

若 i 是核心点且 $j \in N_\varepsilon(i)$ ，称 j 从 i **直接密度可达** (directly density-reachable)。沿这样的有向关系组成有限链，就得到**密度可达** (density-reachable)：链上除终点外的点都须为核心点，终点可以是边界点。若存在一个核心点，使两个样本都从它密度可达，则称它们**密度相连** (density-connected)。

一个无歧义的理解方式是先只保留核心点，把距离不超过 ε 的核心点相连。每个连通分量构成一个簇的核心，再吸收邻接的非核心点。某个边界点可能邻接多个核心分量，因此“极大密度相连集合”在全部样本上未必互不相交；实际 DBSCAN 通常把共享边界点交给先访问到它的簇。图 4.3 展示了核心点负责扩展、边界点只被吸收的差别。




图 4.3 DBSCAN 的教学示意，取 $\varepsilon = 1$ 、 $\text{MinPts} = 4$ ，计数包含自身。圆形和方形分别标识两个核心分量，颜色只作辅助；实心标记为核心点，浅色填充标记为边界点，红框叉号为噪声。虚线圆表示两个示例核心点的邻域；左侧标注直接给出邻域内计数，边界点不能继续扩展簇。

4.2.1.2 参数学习

DBSCAN 的主要工作是查询邻域并搜索核心连通分量。代码 4.3 使用暴力距离查询，完整展示暂定噪声被重新吸收为边界点的情况。

代码 4.3 DBSCAN 的邻域扩展

```

1 import numpy as np
2 from collections import deque
3
4 def dbscan(X, eps, min_pts):
5     X = np.asarray(X, dtype=float)
6     if eps <= 0 or min_pts < 1:
7         raise ValueError("invalid density parameters")
8     labels = np.full(len(X), -1) # -1 未访问, -2 噪声
9     def neighbors(i):
10         d2 = ((X - X[i]) ** 2).sum(1)
11         return np.flatnonzero(d2 <= eps ** 2)
12     cid = 0
13     for i in range(len(X)):
14         if labels[i] != -1:
15             continue
16         near = neighbors(i)
17         if len(near) < min_pts:
18             labels[i] = -2
19             continue
20         labels[i] = cid
21         queue = deque(near)
22         while queue:
23             j = queue.popleft()
24             if labels[j] == -2:
25                 labels[j] = cid
26             if labels[j] != -1:
27                 continue
28             labels[j] = cid
29             near_j = neighbors(j)
30             if len(near_j) >= min_pts:
31                 queue.extend(near_j)
32         cid += 1
33     return labels

```

每个样本至多发起一次邻域查询，但队列可能包含重复索引。暴力实现的距离成本为 $O(n^2d)$ ；低维且邻域规模受控时，空间索引可使实践成本接近 $O(n \log n)$ ，然而高维或大半径下仍可能退化到平方级。预存全部邻域的实现还可能占用 $O(n^2)$ 内存。

参数选择可从第 m 近邻距离的排序图入手，近邻计数约定应与是否包含自身一致。曲线的转折提示不同密度尺度，但未必存在清晰肘部。Schubert 等把 $\text{MinPts} \approx 2d$ 作为平滑密度估计的经验起点，而不是一般最优值²¹。

重复样本、噪声比例和有效维数都会影响合理的邻域大小与最小样本数。

4.2.1.3 理论分析

收敛性分析 DBSCAN 对有限样本的访问和邻域扩展会在有限步后结束。它没有需要反复优化到驻点的连续参数，因此这里更关键的性质是：算法停止时是否完整找到核心连通分量，以及结果是否依赖访问顺序。

定理 4.2 DBSCAN 的核心点确定性 固定数据、对称相异度和参数 (ε, m) ，DBSCAN 输出的每个簇限制到核心点后，恰为核心点邻接图的一个连通分量。因此核心点划分与访问顺序无关，簇编号的置换除外。

证明. 在核心点集合上，距离不超过 ε 的两点能相互直接密度到达。有限链的连通关系满足自反、对称和传递性，故图的连通分量就是核心点上密度相连关系的等价类。

从任一尚未访问的核心点扩展时，每发现一个核心邻居就加入它的邻域。沿路径长度归纳，该点所在连通分量中的每个核心点最终都会被访问。反过来，扩展过程只能经由核心点邻接边到达其他核心点，不能穿过非核心边界点连接两个分量。因此输出的核心集合既不遗漏本分量，也不包含其他分量，结论成立。 ■

共享边界点的归属可能随顺序变化，这不与定理矛盾。

泛化分析 新增样本可能改变邻域计数，使边界点变为核心点，甚至桥接两个原有分量；因此“固定数据的确定性”不能解释为“加入噪声后结构不变”。

DBSCAN 通常是描述已有样本的算法。若希望给新样本预测簇标记，可检查它是否邻接已知核心点，并另设冲突和拒绝规则；这与把新样本加入数据后重新运行 DBSCAN 不完全相同。密度尺度不均时，较小 ε 容易使稀疏簇断裂，较大 ε 又可能合并邻近稠密簇。

4.2.1.4 小结

DBSCAN 用局部计数和连通性发现簇，无需给定 K ，并显式标记噪声。它的边界在于全局密度尺度、邻域度量和高维查询成本；所谓任意形状，是指不预设中心形状，并不保证任何视觉上可辨认的群体都满足其密度连通定义。

²¹ E. Schubert, J. Sander, M. Ester, H.-P. Kriegel, X. Xu, *DBSCAN Revisited, Revisited: Why and How You Should (Still) Use DBSCAN* In ACM Transactions on Database Systems, 2017, vol. 42, no. 3, pp. 1–21

4.2.2 OPTICS

反复调整 DBSCAN 的半径会重复查询相似邻域。OPTICS (Ordering Points To Identify the Clustering Structure) 保留一次搜索中的密度排序, 使分析者能够事后读取不同尺度的结构。Ankerst 等在 1999 年提出的方法输出排序与距离记录, 而非直接输出唯一划分²²。

从 DBSCAN 到 OPTICS, 改变的不只是半径的取值方式, 还包括算法交给分析者的结果形式: 前者给定尺度后输出一组簇标记, 后者先保存可供多个尺度读取的结构。这个选择把探索不同密度群组的工作, 从反复训练转移到了对同一结果的解释与提取。

²² M. Ankerst, M. M. Breunig, H.-P. Kriegel, J. Sander, *OPTICS: Ordering Points to Identify the Clustering Structure* In Proceedings of the ACM SIGMOD International Conference on Management of Data, 1999, pp. 49–60

4.2.2.1 模型结构

设搜索半径上限为 $\varepsilon_{\max}$ 。若样本 i 在该半径内有至少 m 个邻居, 则其**核心距离** (core distance) 为第 m 近邻距离; 否则记为 $+\infty$:

$$a_i = \begin{cases} \delta_{i,(m)}, & |N_{\varepsilon_{\max}}(i)| \geq m, \\ +\infty, & \text{其他情况.} \end{cases}$$

由核心点 i 到邻居 j 的**可达距离** (reachability distance) 定义为

$$r(j | i) = \max\{a_i, \delta(\mathbf{x}_i, \mathbf{x}_j)\}. \quad (4.10)$$

方向来自出发点的核心距离, 因此通常 $r(j | i) \neq r(i | j)$ 。它表示在确保出发点足够密集的同时覆盖 j 所需的半径。

OPTICS 为每个样本记录访问次序、核心距离和当前获得的最小可达距离。按访问次序画出可达距离形成**可达图** (reachability plot); 低谷通常对应容易从内部到达的密集区域, 较高的过渡位置提示区域之间的分隔。

4.2.2.2 参数学习

从一个未处理点开始, 算法输出该点并查询邻域。如果它是核心点, 就用式 (4.10) 更新未处理邻居的最小可达距离; 优先队列每次取出当前可达距离最小的点, 继续同样的过程。队列为空而仍有未处理点时, 再开始一个新的搜索。这个过程是按可达距离优先的遍历, 而不是普通先进先出的广度优先搜索。

给定 $\varepsilon' \leq \varepsilon_{\max}$, 提取 DBSCAN 式结构时必须同时使用核心距离。沿排序扫描, 若某点的记录可达距离大于 ε' , 但核心距离不大于 ε' , 它应开启一个新簇; 若二者都大于阈值, 才暂记为噪声; 可达距离不大于阈值的点接续当前簇。只把水平线下的连续段当作簇, 会漏掉可达距离很大、却负责开启新簇的核心点。不同提取规则对部分边界点的处理还可能与重新运

行 DBSCAN 不同。

图 4.4 将原始样本间距与可达图对应起来。中间一组样本较稀疏，形成的谷底较高；用 $\epsilon' = 0.35$ 提取时它们不构成核心簇，增大阈值才会纳入。次序 1、8、14 对应三次重新开始的搜索，其可达距离为无穷；次序 23 的孤立点也有无穷可达距离，但它的核心距离同样无穷，因而不能开启簇。




图 4.4 固定一维教学数据上的 OPTICS 排序，取 $\text{MinPts} = 3$ (含自身)、 $\epsilon_{\max} = 1.1$ 。三组样本的间距分别为 0.15、0.4、0.1，另有 $x = 12$ 的孤立点。红色竖棒为可达距离，蓝色虚线为核心距离；蓝、黄底色标出两个低谷。无穷可达距离用顶部三角形表示，不能按其显示高度作数值比较；水平点划线展示阈值切割在本例中提取哪些低谷。

若希望自动找出不同深度的低谷，可用基于相对陡降和陡升的 ξ 规则，再结合最小簇规模、先驱关系和嵌套处理。原始 OPTICS 已讨论陡峭区域提取，后续工作进一步研究从排序构造密度层次；这些方法都依赖提取参数，不能理解为完全消除了尺度选择。

4.2.2.3 小结

OPTICS 的价值在于把邻域计算与粒度探索分开。它保留多尺度信息，却仍受 $\epsilon_{\max}$ 、 MinPts 和提取规则影响。空间索引有效且邻域输出受控时可获得较好扩展性，最坏情况仍可能为平方级；优先队列和额外记录也使成本通常高于一次 DBSCAN，具体倍率取决于实现和数据。

4.2.3 Mean Shift

密度连通性描述“能否沿密集区域走通”，但有时更想知道样本会聚向哪个密度峰。**均值漂移** (Mean Shift) 从当前位置计算一个局部加权均值，再向该均值移动，用重复更新寻找密度估计的驻点。

这条路线早于 DBSCAN。Fukunaga 与 Hostetler 在 1975 年研究如何从样本估计密度梯度，并将局部均值偏移与模式识别联系起来²³。它的出发点是估计“密度朝哪个方向增加”，因此不必先明确列出簇的边界。

Cheng 在 1995 年进一步讨论核与权重的推广，说明均值漂移、模态搜索和聚类之间的关系²⁴。Comaniciu 与 Meer 在 2002 年系统分析这一方法并展示其在特征空间与图像分割中的用途，使它成为视觉任务中常用的局部聚集工具²⁵。这段历史也提示我们，Mean Shift 的基本对象是密度估计上的移动轨迹，簇分配是在轨迹之后得到的。

4.2.3.1 模型结构

以径向核估计未知密度。设 $h > 0$ 为带宽，核函数为 $\mathcal{K}(\mathbf{u}) = c_k k(\|\mathbf{u}\|_2^2)$ ，其中 c_k 是归一化常数， k 称为核的 profile。则**核密度估计**（kernel density estimation, KDE）为

$$\hat{f}(\mathbf{y}) = \frac{c_k}{nh^d} \sum_{i=1}^n k\left(\frac{\|\mathbf{y} - \mathbf{x}_i\|_2^2}{h^2}\right). \quad (4.11)$$

把每个样本作为起点，在估计密度上迭代；趋向同一模态的起点归为一簇。带宽决定平滑尺度，小带宽通常保留更多局部细节，大带宽通常合并邻近结构；在高维一般情形下，不应把模态数量随带宽变化说成无条件严格单调。

4.2.3.2 参数学习

令 $g(u) = -k'(u)$ ，并记 $u_i(\mathbf{y}) = \|\mathbf{y} - \mathbf{x}_i\|_2^2/h^2$ 。直接对式 (4.11) 求导可得

$$\nabla \hat{f}(\mathbf{y}) = \frac{2c_k}{nh^{d+2}} \sum_i g(u_i(\mathbf{y}))(\mathbf{x}_i - \mathbf{y}).$$

只要权重和为正，梯度便是正系数乘以**均值漂移向量**

$$\mathbf{m}(\mathbf{y}) = \frac{\sum_i g(u_i(\mathbf{y}))\mathbf{x}_i}{\sum_i g(u_i(\mathbf{y}))} - \mathbf{y}.$$

因此采用下列自适应步长的梯度方向更新：

$$\mathbf{y}^{(t+1)} = \frac{\sum_i w_i^{(t)} \mathbf{x}_i}{\sum_i w_i^{(t)}}, \quad w_i^{(t)} = g(u_i(\mathbf{y}^{(t)})). \quad (4.12)$$

权重由 profile 的负导数给出，而不是对向量核 $\mathcal{K}$ 直接取一元导数。高斯 profile $k(u) = \exp(-u/2)$ 给出与高斯权重成比例的 g ；Epanechnikov profile $(1-u)_+$ 则在核支撑内部给出常数权重，边界需作分段处理。

式 (4.12) 与第 2.2.2.4 节的 Nadaraya-Watson 核平滑都计算核加权平均，

²³ K. Fukunaga, L. D. Hostetler, *The Estimation of the Gradient of a Density Function, with Applications in Pattern Recognition* In IEEE Transactions on Information Theory, 1975, vol. 21, no. 1, pp. 32–40

²⁴ Y. Cheng, *Mean Shift, Mode Seeking, and Clustering* In IEEE Transactions on Pattern Analysis and Machine Intelligence, 1995, vol. 17, no. 8, pp. 790–799

²⁵ D. Comaniciu, P. Meer, *Mean Shift: A Robust Approach toward Feature Space Analysis* In IEEE Transactions on Pattern Analysis and Machine Intelligence, 2002, vol. 24, no. 5, pp. 603–619

但平均对象和任务不同：Mean Shift 平均输入位置以更新搜索点，核回归则平均响应以预测条件均值。

图 4.5 展示了式 (4.12) 的一维轨迹。两个起点分别移向左右密度峰，而且接近峰值后每一步的位移变小。灰色曲线使用同一组样本但更大的带宽，此时原先的两个峰被平滑为一个峰；这说明决定簇数的是估计密度的形状，而不仅是起点的数量。




图 4.5 Mean Shift 的密度爬升与带宽效应。左右各有三个样本，位置为 $-2.5, -2, -1.5$ 和 $1.5, 2, 2.5$ ，均采用高斯核。彩色标记给出带宽 $h = 0.6$ 时从 ± 0.8 出发的初始位置和四次更新，箭头指示第一次移动；灰色虚线对应 $h = 2.4$ ，轨迹在黑色实线上计算。

代码 4.4 高斯 Mean Shift 的起点更新

```
1 import numpy as np
2
3 def mean_shift_positions(X, h, max_iter=300, tol=1e-4):
4     X = np.asarray(X, dtype=float)
5     if h <= 0:
6         raise ValueError("h must be positive")
7     Y = X.copy()
8     for _ in range(max_iter):
9         d2 = ((Y[:, None] - X[None]) ** 2).sum(2)
10        log_w = -d2 / (2 * h * h)
11        log_w -= log_w.max(1, keepdims=True)
12        W = np.exp(log_w)
13        new = (W @ X) / W.sum(1, keepdims=True)
14        step = np.linalg.norm(new - Y, axis=1).max()
15        Y = new
16        if step <= tol:
17            break
```

18 `return Y`

返回值是最终位置，尚需合并近邻终点才能得到簇分配。可构造终点间距离不超过 ρ 的图并取连通分量，例如用 $\rho = h/2$ 作为教学起点；这种阈值合并是另一个启发式，可能链式合并不同模态，应与迭代容差区分。

对全部 n 个起点做一轮精确更新需要 $O(n^2d)$ 运算。高斯核具有无限支撑，截断邻域或近似近邻会改变精确更新；空间索引并不能无条件把它降成 $O(n \log n)$ 。实际可采用分块计算、减少起点或有限支撑核，但应说明相应近似。

4.2.3.3 理论分析

收敛性分析 密度值增加与位置收敛是两个命题。经典分析中的上升不等式可直接证明前者；从步长平方可和到位置收敛，还需要补充条件。后续研究专门指出了把平方可和误当作 Cauchy 性的问题²⁶。

定理 4.3 Mean Shift 的密度单调性与条件收敛 设 k 非负、凸、非增且可微， $k(0) < \infty$ ，迭代中权重和始终为正。则式 (4.12) 产生的密度值单调不减且收敛。若进一步假设 $g = -k'$ 连续且严格为正，样本凸包内的固定点只有有限个，则位置序列也收敛，极限为 $\hat{f}$ 的驻点。

²⁶ Y. Aliyari Ghassabeh, *A Sufficient Condition for the Convergence of the Mean Shift Algorithm with Gaussian Kernel* In Journal of Multivariate Analysis, 2015, vol. 135, pp. 1–10

证明. 简记 $\mathbf{y} = \mathbf{y}^{(t)}$ 、 $\mathbf{y}' = \mathbf{y}^{(t+1)}$ 。由凸性，

$$k(u_i(\mathbf{y}')) - k(u_i(\mathbf{y})) \geq g(u_i(\mathbf{y}))(u_i(\mathbf{y}) - u_i(\mathbf{y}')).$$

令 $w_i = g(u_i(\mathbf{y}))$ 、 $s = \sum_i w_i$ 。由于 $\mathbf{y}'$ 是加权均值，展开平方后交叉项为零，得到

$$\sum_i w_i (\|\mathbf{y} - \mathbf{x}_i\|_2^2 - \|\mathbf{y}' - \mathbf{x}_i\|_2^2) = s \|\mathbf{y}' - \mathbf{y}\|_2^2.$$

所以

$$\hat{f}(\mathbf{y}') - \hat{f}(\mathbf{y}) \geq \frac{c_k s}{nh^{d+2}} \|\mathbf{y}' - \mathbf{y}\|_2^2 \geq 0. \quad (4.13)$$

又有 $\hat{f}(\mathbf{y}) \leq c_k k(0)/h^d$ ，故密度值收敛。

在附加条件下，第一次更新后所有位置均在有限样本的紧凸包内。距离平方因此有界，而连续正函数 g 在相应紧区间上有正下界，故 s 也有统一正下界。对式 (4.13) 求和，得到步长平方可和，特别地， $\|\mathbf{y}^{(t+1)} - \mathbf{y}^{(t)}\|_2 \rightarrow 0$ 。

记连续更新映射为 T 。任取收敛子列 $\mathbf{y}^{(t_j)} \rightarrow \mathbf{y}^*$ ，步长趋零与连续性给出 $T(\mathbf{y}^*) = \mathbf{y}^*$ ，所以每个聚点都是固定点。固定点有限，取彼此不相交的小球包围它们；序列最终必在这些小球的并集中，否则紧性会产生球外聚

点。步长最终小于球之间的间隙，故序列不能从一个球跳到另一个球。任意缩小球半径，便知它只能趋向其中一个固定点。梯度公式最后给出 $\nabla \hat{f}(\mathbf{y}^*) = \mathbf{0}$ 。 ■

证明没有把“平方可和”直接当作 Cauchy 性；真正排除多个极限位置的是紧性、连续性和有限固定点条件。极限是驻点，不保证总是局部极大值；从鞍点等特殊位置出发可能停在那里。Epanechnikov 核的不可微边界和零权重还需单独分析，不能直接套用定理的第二部分。

泛化分析 模态聚类对带宽和密度估计误差敏感。KDE 在适当光滑性、带宽随 n 缩小等条件下有统计一致性，但从密度估计一致到模态位置、吸引域乃至簇分配稳定，还需要额外正则条件。算法的上升性质只涉及当前数据上的固定估计密度。

4.2.3.4 小结

Mean Shift 用局部均值更新实现密度爬升，把簇解释为模态的吸引域。它不显式指定 K ，却需要选择带宽、起点和终点合并规则。图像分割与跟踪利用了这种局部聚集能力；计算成本、非极大驻点和带宽敏感性仍是使用时的边界。

4.2.4 模型对比与总结

本小节先比较 DBSCAN、OPTICS 与 Mean Shift，再把结合网格或层次选择的密度方法作为代表性扩展。DBSCAN 识别固定尺度下的核心连通区域，OPTICS 保留可用于多尺度提取的排序，Mean Shift 则追踪平滑密度的驻点。一个连通密集区域可以含多个峰，因此三者即使采用相近尺度，也可能给出不同划分。需要噪声标记时应确认算法是否显式提供拒绝机制，而不能把所有密度方法视为等价。

DENCLUE 用样本影响函数叠加构造密度，再以密度吸引点及其连通关系组织簇；密度阈值承担噪声处理，网格结构辅助计算。它与 Mean Shift 共享密度估计视角，但不能据此认为它自动解决了高维密度估计问题²⁷。

HDBSCAN 把核心距离用于定义**互可达距离**（mutual reachability distance）：

$$\delta_{\text{mr}}(i, j) = \max\{a_i, a_j, \delta(\mathbf{x}_i, \mathbf{x}_j)\}.$$

在这一距离上构造最小生成树并形成密度层次，再按最小簇规模压缩层次、按跨尺度持续性选择簇，可以减轻单一 ε 的限制。Campello 等给出了这一层次密度框架²⁸。

这里的“稳定性”是特定的层次选择量，并非对所有扰动的统计稳健性证明。HDBSCAN 仍需选择最小簇规模等参数；网格、索引和层次都不能

²⁷ A. Hinneburg, D. A. Keim, *An Efficient Approach to Clustering in Large Multimedia Databases with Noise* In Proceedings of the Fourth International Conference on Knowledge Discovery and Data Mining, 1998, pp. 58–65

²⁸ R. J. G. B. Campello, D. Moulavi, J. Sander, *Density-Based Clustering Based on Hierarchical Density Estimates* In Advances in Knowledge Discovery and Data Mining, 2013, pp. 160–172

保证高维距离具有足够区分度。密度方法的价值，在于让低密度分隔进入簇定义；若已知的主要信息是样本之间的关系，则可以进一步转向图。

4.3 基于图的聚类

社交网络中的连接、文档之间的相似度或图像像素的邻接关系，都可以直接构成加权图，不一定先转换成欧氏坐标。基于图的聚类把样本视为顶点，把相似程度视为边权，希望簇内连接较强、簇间连接较弱。距离也可以用来构图；转向图并不意味着结果不再依赖相似性设计。

最小图割能表达连接稀疏，却容易偏向切下小块。加入规模归一化后，可以更明确地权衡切边代价与簇体积；谱聚类则把相应离散问题松弛为连续的特征向量问题。

4.3.1 谱聚类

谱聚类 (spectral clustering) 使用图拉普拉斯矩阵的特征向量表示顶点，再在新表示上划分。它与第5.3.3节的拉普拉斯特征映射共享建图、拉普拉斯矩阵与低频特征向量，但前者把谱表示离散为簇分配，后者输出连续低维坐标。von Luxburg 的教程整理了不同图构造、归一化方式及其适用条件²⁹。其理论源于图分割与代数连通性的研究；Shi 与 Malik 的归一化割把这一思路用于图像分割，Ng、Jordan 与 Weiss 给出了常用的多簇算法。

早期谱方法关注的是图分割本身。Donath 与 Hoffman 在 1973 年利用矩阵的谱信息建立图划分代价的下界，把难以直接搜索的组合问题与可计算的特征值联系起来³⁰。后来，Shi 与 Malik 将图像像素间的相似关系写成归一化割目标，相关工作于 1997 年在会议上发表，2000 年形成期刊论文³¹。Ng、Jordan 与 Weiss 在 2001 年会议上的工作进一步给出了多簇谱嵌入与行归一化方案，其论文集出版于 2002 年³²。谱聚类由此形成了“建图、求低频表示、再离散化”的常用流程。

4.3.1.1 模型结构

设无向图的非负对称权重矩阵为 $\mathbf{W} \in \mathbb{R}^{n \times n}$ ，通常令 $w_{i,i} = 0$ 。向量样本可用高斯相似度 $\exp(-\|\mathbf{x}_i - \mathbf{x}_j\|_2^2 / (2\sigma^2))$ 构造边；近邻图则保留部分局部关系。单向近邻关系未必对称，必须明确采用并集对称化还是互近邻规则。

定义顶点度 $d_i = \sum_j w_{i,j}$ 、度矩阵 $\mathbf{D} = \text{diag}(d_1, \dots, d_n)$ ，以及三种拉普拉斯：

$$\begin{aligned} \mathbf{L} &= \mathbf{D} - \mathbf{W}, \\ \mathbf{L}_{\text{sym}} &= \mathbf{I} - \mathbf{D}^{-1/2} \mathbf{W} \mathbf{D}^{-1/2}, \\ \mathbf{L}_{\text{rw}} &= \mathbf{I} - \mathbf{D}^{-1} \mathbf{W}. \end{aligned} \quad (4.14)$$

²⁹ U. von Luxburg, *A Tutorial on Spectral Clustering* In Statistics and Computing, 2007, vol. 17, no. 4, pp. 395–416

³⁰ W. E. Donath, A. J. Hoffman, *Lower Bounds for the Partitioning of Graphs* In IBM Journal of Research and Development, 1973, vol. 17, no. 5, pp. 420–425

³¹ J. Shi, J. Malik, *Normalized Cuts and Image Segmentation* In IEEE Transactions on Pattern Analysis and Machine Intelligence, 2000, vol. 22, no. 8, pp. 888–905

³² A. Y. Ng, M. I. Jordan, Y. Weiss, *On Spectral Clustering: Analysis and an Algorithm* In Advances in Neural Information Processing Systems, 2002, pp. 849–856

后两式要求 $d_i > 0$ ；孤立顶点应单独处理。 $\mathbf{L}_{\text{rw}}$ 一般不对称，但与 $\mathbf{L}_{\text{sym}}$ 相似，因而有相同的实特征值。对任意 $\mathbf{v} \in \mathbb{R}^n$,

$$\mathbf{v}^\top \mathbf{L} \mathbf{v} = \frac{1}{2} \sum_{i,j} w_{i,j} (v_i - v_j)^2 \geq 0. \quad (4.15)$$

所以 $\mathbf{L}$ 半正定，且 $\mathbf{L}\mathbf{1} = \mathbf{0}$ ；零特征值的重数等于连通分量数，图连通时才为单重。

归一化还具有随机游走解释。转移矩阵 $\mathbf{P} = \mathbf{D}^{-1}\mathbf{W}$ 让游走者按边权比例选择下一顶点，且 $\mathbf{L}_{\text{rw}} = \mathbf{I} - \mathbf{P}$ 。从一个簇出发，若内部连接强而外部连接弱，游走就倾向在簇中停留较久；Meilă 与 Shi 据此研究了聚类的随机游走视角³³。

设 $\text{cut}(A, \bar{A}) = \sum_{i \in A, j \notin A} w_{i,j}$, $\text{vol}(A) = \sum_{i \in A} d_i$ 。归一化割 (normalized cut, NCut) 定义为

$$\text{NCut}(\mathcal{P}) = \sum_{k=1}^K \frac{\text{cut}(C_k, \bar{C}_k)}{\text{vol}(C_k)}. \quad (4.16)$$

它用簇的连接体积归一化切边权重，减轻小簇偏置，而不强制样本数相等³⁴。比率割 (RatioCut) 则把分母换成 $|C_k|$ ，对应未归一化拉普拉斯的松弛。

4.3.1.2 参数学习

为把 NCut 改写成矩阵目标，定义 $\mathbf{F} \in \mathbb{R}^{n \times K}$ ，其中

$$f_{i,k} = \begin{cases} 1/\sqrt{\text{vol}(C_k)}, & i \in C_k, \\ 0, & i \notin C_k. \end{cases}$$

簇互不相交给出 $\mathbf{F}^\top \mathbf{D} \mathbf{F} = \mathbf{I}_K$ 。由式 (4.15)，第 k 列的二次型恰为第 k 项归一化割，故目标为 $\text{tr}(\mathbf{F}^\top \mathbf{L} \mathbf{F})$ 。

困难在于每行只允许一个特定的非零值。去掉这一离散约束，令 $\mathbf{H} = \mathbf{D}^{1/2} \mathbf{F}$ ，得到

$$\min_{\mathbf{H}^\top \mathbf{H} = \mathbf{I}_K} \text{tr}(\mathbf{H}^\top \mathbf{L}_{\text{sym}} \mathbf{H}). \quad (4.17)$$

Shi-Malik 方法也可写为广义特征问题 $\mathbf{L} \mathbf{f} = \lambda \mathbf{D} \mathbf{f}$ ，与归一化变换相联系³⁵。取 $\mathbf{L}_{\text{sym}}$ 最小的 K 个特征值对应的特征向量，即得到式 (4.17) 的最优解，下节给出证明。

连续解还需离散化。**NJW 算法**把 $\mathbf{H}$ 每一行归一化到单位长度，再对向量运行 K-means³⁶。若图恰有 K 个连通分量，理想谱空间中每个分量对应同一方向；行归一化消除度数造成的长度差异，图 4.6 展示了这一解释。

³³ M. Meilă, J. Shi, *A Random Walks View of Spectral Segmentation* In Proceedings of the Eighth International Workshop on Artificial Intelligence and Statistics, 2001, pp. 203–208

³⁴ J. Shi, J. Malik, *Normalized Cuts and Image Segmentation* In IEEE Transactions on Pattern Analysis and Machine Intelligence, 2000, vol. 22, no. 8, pp. 888–905

³⁵ J. Shi, J. Malik, *Normalized Cuts and Image Segmentation* In IEEE Transactions on Pattern Analysis and Machine Intelligence, 2000, vol. 22, no. 8, pp. 888–905

³⁶ A. Y. Ng, M. I. Jordan, Y. Weiss, *On Spectral Clustering: Analysis and an Algorithm* In Advances in Neural Information Processing Systems, 2002, pp. 849–856

连接较弱的实际图中，这只是近似结构。




图 4.6 谱聚类的理想情形：圆形与方形分别标识两个互不连接的分量，颜色只作辅助；在归一化谱空间中，两个分量分别落到两个方向。细虚线表示实际数据中可能存在的弱连接；加入这些连接后，谱坐标通常形成近似群组。

代码 4.5 给定相似度矩阵的 NJW 算法

```

1 import numpy as np
2 from scipy.linalg import eigh
3
4 def spectral_clustering(W, K):
5     W = np.asarray(W, dtype=float)
6     n = len(W)
7     if W.shape != (n, n) or not 1 <= K <= n:
8         raise ValueError("invalid shape or K")
9     if (W < 0).any() or not np.allclose(W, W.T):
10        raise ValueError("W must be nonnegative and
11        symmetric")
12    degree = W.sum(1)
13    if (degree <= 0).any():
14        raise ValueError("handle isolated vertices first")
15    inv = 1 / np.sqrt(degree)
16    L = np.eye(n) - inv[:, None] * W * inv[None, :]
17    _, H = eigh(L, subset_by_index=[0, K - 1])
18    length = np.linalg.norm(H, axis=1)
19    if (length == 0).any():
20        raise ValueError("zero embedding row")
21    labels, _ = kmeans(H / length[:, None], K)
22    return labels

```

代码调用代码 4.1 的函数，适用于可放入内存的稠密矩阵。若图的连通分量数超过 K ，选出的零特征子空间可能造成零行或任意合并，宜先分析连通分量，再确定分配策略。

构造稠密相似度通常需要 $O(n^2d)$ 距离计算和 $O(n^2)$ 存储，完整特征分解需 $O(n^3)$ 运算。仅求部分特征向量可使用 Lanczos 或 LOBPCG；单次矩阵乘法可按稀疏边数计费，但总成本还取决于特征间隙、精度和迭代次数，不能简单保证为 $O(n^2K)$ 或线性。近邻建图与 Nyström 等近似也是大规模

实现的重要部分。

4.3.1.3 理论分析

收敛性分析 谱聚类包含特征求解和簇分配离散化两个计算阶段。迭代特征求解器需找到最小的 K 个特征值及其特征子空间，并满足给定残差精度；随后的 K-means 仍有自己的初始化和停止条件。下面先确定谱子问题应当收敛到什么目标值：连续松弛可以全局求解，但这一性质不自动传给原始图割或最后的 K-means。

定理 4.4 Rayleigh–Ritz 迹最小化 设对称矩阵 $B \in \mathbb{R}^{n \times n}$ 的特征值为 $\lambda_1 \leq \dots \leq \lambda_n$ ，对应正交单位特征向量为 $\mathbf{u}_1, \dots, \mathbf{u}_n$ 。则

$$\min_{H^T H = I_K} \text{tr}(H^T B H) = \sum_{k=1}^K \lambda_k.$$

取 $H = [\mathbf{u}_1, \dots, \mathbf{u}_K]$ 可达到最优。若 $K < n$ 且 $\lambda_K < \lambda_{K+1}$ ，最优列空间唯一，基仅相差右乘正交矩阵。

证明. 令 U 为全部特征向量组成的正交矩阵， $A = U^T B U$ ，则 $A^T A = I_K$ 。记 $b_i = \sum_{k=1}^K a_{i,k}^2$ ，由于 AA^T 是正交投影矩阵， $0 \leq b_i \leq 1$ 且 $\sum_i b_i = K$ 。目标于是成为 $\sum_i \lambda_i b_i$ 。比较它与前 K 项之和：

$$\begin{aligned} \sum_i \lambda_i b_i - \sum_{i \leq K} \lambda_i &= \sum_{i > K} \lambda_i b_i - \sum_{i \leq K} \lambda_i (1 - b_i) \\ &\geq \lambda_K \left[\sum_{i > K} b_i - \sum_{i \leq K} (1 - b_i) \right] = 0. \end{aligned}$$

取前 K 个特征向量时达到等号。有严格边界间隙时，等号迫使前 K 个方向承载全部投影，因而列空间唯一；边界特征值重复时，可以在该重特征空间内选择不同子空间，唯一性不再成立。 ■

图割质量与谱量之间还存在 Cheeger 型联系。对连通、非负无向图，定义**电导** (conductance)

$$\phi(S) = \frac{\text{cut}(S, \bar{S})}{\min\{\text{vol}(S), \text{vol}(\bar{S})\}}, \quad h_G = \min_{\emptyset \neq S \neq V} \phi(S).$$

若 λ_2 是 L_{sym} 的第二小特征值，则

$$\frac{\lambda_2}{2} \leq h_G \leq \sqrt{2\lambda_2}. \quad (4.18)$$

图上的这类不等式把低频特征向量与稀疏切割联系起来，标准谱图论教材给出了证明及其与流形版本的关系³⁷。

³⁷ F. R. K. Chung, *Spectral Graph Theory*, American Mathematical Society, 1997, 1st ed.

这里 h_G 是最小电导, 不是直接把 NCut 换个名字。二分情形满足 $\phi(S) \leq \text{NCut}(S, \bar{S}) \leq 2\phi(S)$ 。若 $\mathbf{u}$ 是 $\mathbf{L}_{\text{sym}}$ 的第二特征向量, 则

$$\mathbf{f} = \mathbf{D}^{-1/2} \mathbf{u}, \quad \mathbf{L} \mathbf{f} = \lambda_2 \mathbf{D} \mathbf{f}, \quad \mathbf{L}_{\text{rw}} \mathbf{f} = \lambda_2 \mathbf{f}.$$

因此, Cheeger sweep 应按 $f_i = u_i / \sqrt{d_i}$ 排序并扫描阈值; 若直接求广义特征问题或随机游走拉普拉斯, 排序坐标就是其特征向量 $\mathbf{f}$ 。只有各顶点度数相同时, 按 $\mathbf{u}$ 与按 $\mathbf{f}$ 排序才必然相同。该结果不能直接视为任意多簇 NJW 加 K-means 的同一近似保证。

泛化分析 统计一致性同样有条件。von Luxburg、Belkin 与 Bousquet 研究了固定相似核下经验谱对象向总体积分算子的收敛³⁸。结论需要核、度函数和谱隔离等假设。归一化与未归一化方法的条件并不相同, 离散簇分配还依赖舍入稳定性。

若研究流形上的拉普拉斯-贝尔特拉米极限, 还需另设带宽随样本量变化、流形光滑性、采样密度与归一化条件; 它不是固定核一致性定理的直接同义表述。K-means 和密度估计也有各自的一致性研究, 不能把渐近理论视为谱聚类独有。

4.3.1.4 小结

谱聚类通过关系图表达非凸结构, 通过特征分解求解连续松弛。结果质量取决于图是否保留了期望的群组结构, 也取决于离散化。特征值间隙可帮助探索 K , 但噪声、弱连接或孤立分量都可能制造间隙; 它应作为诊断线索, 而非唯一判据。

4.3.2 模型对比与总结

本小节先比较谱聚类中的图构造、松弛与离散化, 再把不同图目标和求解机制作为代表性扩展。图上的群组还可以通过消息传递或社区目标寻找。

近邻传播 (Affinity Propagation, AP) 把每个样本作为潜在代表, 以适合度和可用度两类消息协调代表选择。给定相似度 $s(i, k)$, 其典型更新为

$$r(i, k) = s(i, k) - \max_{k' \neq k} \{a(i, k') + s(i, k')\},$$

$$a(i, k) = \min \left\{ 0, r(k, k) + \sum_{i' \notin \{i, k\}} \max\{0, r(i', k)\} \right\}, \quad i \neq k,$$

而 $a(k, k) = \sum_{i' \neq k} \max\{0, r(i', k)\}$ 。适合度衡量候选相对其他代表的优势, 可用度汇总其他样本对该代表的支持。对角相似度 $s(k, k)$ 是偏好参数, 间接控制代表数; 通常还需阻尼以缓解振荡, 迭代不保证总收敛³⁹。

³⁸ U. von Luxburg, M. Belkin, O. Bousquet, *Consistency of Spectral Clustering In The Annals of Statistics*, 2008, vol. 36, no. 2, pp. 555–586

³⁹ B. J. Frey, D. Dueck, *Clustering by Passing Messages between Data Points In Science*, 2007, vol. 315, no. 5814, pp. 972–976

要从消息得到划分, 对每个样本比较两类消息之和, 并按预定的平局规则选择代表索引

$$e_i \in \arg \max_k \{a(i, k) + r(i, k)\}.$$

同一代表对应同一簇, 即 $C_k = \{i : e_i = k\}$ 。输出前还需检查代表选择已连续若干轮保持稳定, 并且相互一致: 若某个样本选择 k 作代表, 就应有 $e_k = k$, 也就是代表选择自己。中间迭代的逐行最大值未必满足这一条件; 选择仍变化或出现不一致时, 应继续迭代或报告未收敛, 不能直接把它当作最终分组。

社区发现中的 Louvain 方法则优化**模块度** (modularity), 比较实际簇内边权与保留度数的随机基准。令 $2m_G = \sum_i d_i$, 典型目标为

$$Q = \frac{1}{2m_G} \sum_{i,j} \left(w_{i,j} - \frac{d_i d_j}{2m_G} \right) 1_{\{c_i = c_j\}}.$$

算法交替执行局部顶点移动与社区凝聚, 在稀疏图上通常较高效; 但它有分辨率限制、顺序敏感性和局部最优问题, 不能与 NCut 的谱松弛保证混用⁴⁰。

这些图方法共同把关系作为输入, 却优化不同的对象。选择时需先确认要找的是低电导集合、典型代表还是高模块度社区; 对于原本就是图的数据, 这种区分比笼统比较“哪种聚类更强”更有意义。

4.4 基于网格与子空间的聚类

样本量扩大时, 反复访问点对关系可能过于昂贵; 维数增多时, 大量无关特征又可能掩盖局部群组。在某些高维分布下, 最近和最远距离的相对差异会缩小, 形成距离集中; 但维数本身并不必然使所有数据失去结构。

基于网格的方法先把样本压缩为单元统计, 主要节省后续区域查询成本。基于子空间的方法则寻找簇在哪些坐标上紧凑, 允许不同簇依赖不同特征。CLIQUE 把这两种思路结合起来, 不过网格单元数和子空间数本身也可能随维数指数增长。

4.4.1 STING

若需要反复查询“哪些区域足够密集”, 可以预先保存区域统计。**统计信息网格** (STatistical Information Grid, STING) 由 Wang、Yang 与 Muntz 在 1997 年提出, 用层次网格组织空间数据, 查询时优先读取摘要⁴¹。

⁴⁰ V. D. Blondel, J.-L. Guillaume, R. Lambiotte, E. Lefebvre, *Fast Unfolding of Communities in Large Networks* In Journal of Statistical Mechanics: Theory and Experiment, 2008, vol. 2008, no. 10, P10008

⁴¹ W. Wang, J. Yang, R. R. Muntz, *STING: A Statistical Information Grid Approach to Spatial Data Mining* In Proceedings of the 23rd International Conference on Very Large Data Bases, 1997, pp. 186–195

4.4.1.1 模型结构

STING 的典型对象是低维空间中的矩形层次网格；二维时每个单元可划成四个子单元。推广到 d 维二分网格时，每次完整细分产生 2^d 个子单元，但不代表必须显式分配全部空单元。

每个单元保存计数、各维均值、标准差、极值及所采用的分布类型估计。为稳定合并统计，可保存计数、和与平方和，再从子单元汇总父单元。分布类型的合并通常只是近似；即使子单元属于同一个分布族，父单元也未必仍属于这个分布族。

4.4.1.2 参数学习

构建阶段扫描样本，确定最细单元并更新统计，再自底向上汇总。固定维数和网格规模时可按 $O(n)$ 扫描成本理解；更完整地计入维数与 G 个已存单元，代价包含 $O(nd + Gd)$ ，还取决于定位单元的数据结构。

查询时，从某层网格出发，依据摘要估计单元满足条件的可能性。例如，对密度条件使用计数，对属性范围条件使用极值或分布近似；排除不相关单元，对保留单元继续下钻。最终可以把满足密度条件且相邻的单元连成区域，必要时回到原始样本作精确检查。

因此 $O(G)$ 描述的是固定摘要上的单元访问成本，不能省略首次读取 n 个样本的代价；若最终精确查询访问了 n_{scan} 个样本，还需计入这部分成本。用估计概率剪枝时，也应区分近似查询与可证明无漏检的确定性筛选。

4.4.1.3 小结

STING 把一次预处理成本换成可重复使用的区域摘要，适合低维空间查询与增量统计。有限分辨率会模糊边界，轴对齐网格对倾斜结构不够精细；深度为 L 的完整二分网格可达 2^{Ld} 个最细单元，所以它本身不是高维问题的通用解。

4.4.2 CLIQUE

某类客户可能仅在消费频次和品类偏好上聚集，年龄等坐标却分散。全维空间没有紧凑簇，不意味着这些低维群组不存在。CLIQUE (CLustering In QUEst) 主动搜索包含密集网格单元的坐标子空间，是 Agrawal 等在 1998 年提出的子空间聚类方法⁴²。

STING 与 CLIQUE 都出现于数据库领域对聚类可扩展性的探索中，但二者把计算节省在不同位置：STING 预存空间统计，减少重复查询的工作；CLIQUE 借鉴频繁模式搜索的逐层筛选思想，减少需要检查的高维组合。它们把数据组织方式纳入聚类设计，而不只是更换一个点间距离。

⁴² R. Agrawal, J. Gehrke, D. Gunopulos, P. Raghavan, *Automatic Subspace Clustering of High Dimensional Data for Data Mining Applications* In Proceedings of the ACM SIGMOD International Conference on Management of Data, 1998, pp. 94–105

4.4.2.1 模型结构

每维划分为 ξ 个区间，区间边界采用统一的半开约定，并把最后端点纳入最后一区间。对特征索引集合 $S \subseteq \{1, \dots, d\}$ ，一个单元 U 是所选坐标上区间的笛卡尔积。定义支持计数

$$n(U) = |\{i : \mathbf{x}_{i,S} \in U\}|.$$

若 $n(U) \geq \tau$ ，则称 U 为**密集单元**（dense unit）。本节使用跨维相同的计数阈值 τ ；使用固定样本比例阈值也等价。不能在未经调整的情况下改用“计数除以单元体积”的跨维阈值。

同一子空间内，两个单元若仅沿一个坐标方向相邻而其他区间相同，就视为邻接；密集单元的极大连通分量构成簇。输出是“子空间与簇”的集合，同一样本可以在不同子空间出现于多个簇，也可以未被任何簇覆盖。图 4.7 表示高维单元投影后样本计数只会增加的关键性质。




图 4.7 CLIQUE 的投影计数示意。二维高亮单元含三个样本，其在横轴区间上的投影还包含其他纵坐标范围的样本。取共同阈值 $\tau = 3$ ，二维单元密集必然推出对应一维单元密集，反方向则不成立。

4.4.2.2 参数学习

CLIQUE 借鉴 Apriori 的逐层候选生成。扫描数据找到一维密集单元后，把具有兼容低维区间的单元连接成更高维候选；只有所有低一维投影都密集的候选才继续计数验证。重复直到候选为空或达到搜索维数上限。

在保留下来的子空间中，算法连接相邻密集单元，形成簇，并可用轴对齐区域的析取式压缩簇描述。原始方法还包含选择子空间和简化描述的步骤；若使用额外启发式筛选，完整性应相对于筛选后的搜索范围表述。

4.4.2.3 理论分析

收敛性分析 CLIQUE 每轮增加候选的维数，最多搜索到 d 维，因此在有限网格上必然结束。除了终止性，还需证明提前剪枝不会遗漏满足计数条件的高维单元；下面的向下封闭性给出这一保证。

定理 4.5 子空间密集性的向下封闭性 在一致的逐维网格和共同计数阈值 τ 下，若 S 上的单元 U 密集，则对任意非空 $S' \subseteq S$ ，其投影 $U|_{S'}$ 也密集。

证明. 记 $I(U) = \{i : \mathbf{x}_{i,S} \in U\}$ 。若 $i \in I(U)$ ，它在 S 的所有选定坐标上都满足区间限制，去掉部分坐标限制后仍然满足。因此

$$I(U) \subseteq I(U|_{S'}), \quad n(U|_{S'}) \geq n(U) \geq \tau.$$

投影网格沿用相同区间，故 $U|_{S'}$ 是合法低维单元，并达到同一密集阈值。 ■

其逆否命题说明：一个低维投影不密集，就可以排除整个高维候选。反向推断不成立，因为不同投影上的样本可能不是同一批。这个性质与维数越高、单元体积越小的连续密度归一化无关；若阈值随维数变化，必须重新证明剪枝条件。

有限网格保证搜索最终结束，但最坏情况下大量投影都密集，仍可能枚举指数多个子空间和单元。

泛化分析 训练集中的密集区域是否对应总体簇，还取决于采样、网格分辨率和阈值选择，Apriori 剪枝本身没有给出泛化保证。一个单元的计数如果恰在阈值附近，更换少量样本便可能改变其密集判定，继而拆开或接通一个网格簇。评估时应同时检查区域计数与连通结构对重采样和网格平移是否敏感，而不能只核对搜索是否完整。

4.4.2.4 小结

CLIQUE 允许簇拥有各自的相关坐标，并利用向下封闭性减少无效搜索。它保留的是网格尺度上的结构：粗网格会混合相邻群体，细网格会稀释计数，轴对齐坐标也限制了子空间形式。MAFIA、SUBCLU 和 DOC/FASTDOC 分别从自适应网格、密度连通及随机化搜索等方向改进这些限制。

4.4.3 模型对比与总结

本小节先比较 STING 与 CLIQUE，再把多分辨率、密度子空间和投影搜索作为代表性扩展。STING 的主要目标是可重复查询的空间摘要，CLIQUE

的主要目标是发现不同坐标子空间中的群组。前者节省后续访问样本的次数，后者避免要求所有簇都在全维空间紧凑；两者的可扩展性都受已存单元或候选规模限制。

WaveCluster 把网格计数看作离散信号，在不同小波尺度上寻找密集区域，并抑制部分高频噪声。它仍保留有限网格分辨率；固定维数、分辨率和变换规模时，读入数据可以是线性的，但不能据此忽略网格变换本身的成本⁴³。

沿子空间路线，SUBCLU 在各子空间使用 DBSCAN 的密度连通性，避免固定网格边界；MAFIA 使用自适应区间改善候选分布；DOC 与 FASTDOC 则用随机抽样寻找投影中紧凑的群组。这些方法共同利用低维结构，但各自需要不同的搜索条件，不能把 CLIQUE 的计数证明原封不动地套到它们全部的剪枝规则上⁴⁴。

投影聚类（projected clustering）通常要求每个样本有唯一簇归属，同时为每簇寻找相关子空间。PROCLUS 使用类似 K-medoids 的代表搜索并选择相关坐标；ORCLUS 进一步学习任意方向的低维正交投影，能够表达相对坐标轴倾斜的群组。前者偏向坐标子集，后者需估计方向，两者的计算与统计代价因此不同。

需要覆盖多个重叠解释时，可考虑 CLIQUE 或 SUBCLU；需要明确硬划分及每簇相关坐标时，可考虑投影方法。高维表示是否包含可恢复的低维结构仍须验证，任何子空间搜索都不能凭空创造这种结构。

4.5 基于层次的聚类

当“应该分几类”尚不明确时，一次性输出 K 个簇会过早固定粒度。**层次聚类**（hierarchical clustering）把簇组织成嵌套结构，用**树状图**（dendrogram）记录合并或分裂过程。分析者可以从同一棵树中选择不同规模的划分，但树本身并不替代粒度选择。

凝聚方法从单点簇向上合并，分裂方法从全集向下拆分。图 4.8 展示了同一层次树上的两种截取粒度；截线只是读取既有层次，不会重新优化该粒度下的目标。

4.5.1 AGNES（凝聚层次聚类）

凝聚分析（Agglomerative Nesting, AGNES）每步合并当前最相似的两簇。凝聚方法在数值分类学中已有长期应用，Kaufman 与 Rousseeuw 在 1990 年的专著中用 AGNES 组织这一分析过程，并将它与自顶向下的 DIANA 对照介绍。与 K-means 不同，AGNES 的关键设计选择是“两个簇之间的相异度怎样计算”。

⁴³ G. Sheikholeslami, S. Chatterjee, A. Zhang, *WaveCluster: A Multi-Resolution Clustering Approach for Very Large Spatial Databases* In Proceedings of the 24th International Conference on Very Large Data Bases, 1998, pp. 428–439

⁴⁴ L. Parsons, E. Haque, H. Liu, *Subspace Clustering for High Dimensional Data: A Review* In ACM SIGKDD Explorations Newsletter, 2004, vol. 6, no. 1, pp. 90–105




图 4.8 教学用层次树。叶节点为六个样本，内部节点高度表示合并相异度。较低截线得到三个簇，较高截线得到两个簇；图中高度为示意数值。

层次方法的发展也体现在链接准则的变化上。单链接沿邻近关系连接样本，平均链接综合全部跨簇距离；Ward 在 1963 年则把一个明确的优化目标引入合并决策，要求每次合并尽量少增加组内平方误差。因而“凝聚”描述的是构造方向，具体形成怎样的树，还要由链接准则决定。

4.5.1.1 模型结构

初始划分为 $\mathcal{P}^{(0)} = \{\{1\}, \dots, \{n\}\}$ 。第 t 步选择使 $D(A, B)$ 最小的两个当前簇，替换为 $A \cup B$ ，经过 $n - 1$ 次合并得到根节点。固定相异度和确定的平局规则后，整棵树随之确定。

不同**链接方式**（linkage）用不同的簇间统计量：

$$\begin{aligned} D_{\text{single}}(A, B) &= \min_{i \in A, j \in B} \delta(\mathbf{x}_i, \mathbf{x}_j), \\ D_{\text{complete}}(A, B) &= \max_{i \in A, j \in B} \delta(\mathbf{x}_i, \mathbf{x}_j), \\ D_{\text{average}}(A, B) &= \frac{\sum_{i \in A, j \in B} \delta(\mathbf{x}_i, \mathbf{x}_j)}{|A||B|}. \end{aligned}$$

单链接沿近邻链扩展，可以保留细长形状，也容易被稀疏桥接点连接起来；全链接控制跨簇最远距离，倾向紧凑群组；平均链接考虑所有跨簇样本对，减弱单个极值的影响。这里的平均链接指按样本数加权的 UPGMA。

若样本处于欧氏空间，Ward 链接以合并引起的 SSE 增量定义相异度：

$$D_{\text{Ward}}(A, B) = \text{SSE}(A \cup B) - \text{SSE}(A) - \text{SSE}(B).$$

它与 K-means 共享平方误差准则，但只允许合并已有簇。Ward 的原始工作明确以这种误差增量组织层次⁴⁵。

⁴⁵ J. H. Ward Jr., *Hierarchical Grouping to Optimize an Objective Function* In Journal of the American Statistical Association, 1963, vol. 58, no. 301, pp. 236–244

4.5.1.2 参数学习

实现 AGNES 时, 可以维护当前簇间的相异度, 并在每次合并后更新相关行列。算法 4.1 省去了不影响定义的矩阵下标管理。

算法 4.1 凝聚层次聚类

输入: 样本相异度、链接方式和确定的平局规则

输出: 包含合并高度的层次树

- 1: 建立 n 个单点簇, 初始化簇间相异度
- 2: **while** 当前簇数大于 1 **do**
- 3: 选择使 $D(A, B)$ 最小的当前簇对
- 4: 记录子簇 A, B 和合并高度 $D(A, B)$
- 5: 用 $A \cup B$ 替换 A, B
- 6: 更新新簇与其他当前簇的相异度
- 7: **end while**

Lance-Williams 递推使多种链接共享更新形式⁴⁶。

$$D(A \cup B, C) = \alpha_A D(A, C) + \alpha_B D(B, C) + \beta D(A, B) + \gamma |D(A, C) - D(B, C)|. \quad (4.19)$$

单链接的系数为 $(1/2, 1/2, 0, -1/2)$, 全链接为 $(1/2, 1/2, 0, 1/2)$, 平均链接为 $(|A|/(|A| + |B|), |B|/(|A| + |B|), 0, 0)$ 。若 D 直接表示 Ward 的 SSE 增量, 令 $s = |A| + |B| + |C|$, 则

$$\alpha_A = \frac{|A| + |C|}{s}, \quad \alpha_B = \frac{|B| + |C|}{s}, \quad \beta = -\frac{|C|}{s}, \quad \gamma = 0.$$

有些软件存储的是 Ward 增量的缩放平方根; 使用递推前必须核对该软件的距离约定。

每轮扫描全部簇对的朴素实现需要 $O(n^3)$ 时间和 $O(n^2)$ 存储。利用链接性质可进一步改进: SLINK 对单链接可达到 $O(n^2)$ 时间和 $O(n)$ 辅助空间; 全链接也有 CLINK 等紧凑表示方法, 但需遵循其算法与平局约定。平均链接、全链接和 Ward 的最近邻链实现可达到 $O(n^2)$ 时间, 常见实现仍保存平方规模的距离矩阵, 不能把 $O(n^2 \log n)$ 当作必然下界⁴⁷。

4.5.1.3 理论分析

收敛性分析 AGNES 每步减少一个簇, 因此有限停止来自计数, 而非某个连续优化的收敛定理。更有意义的问题是每次合并优化了什么。

定理 4.6 Ward 合并的贪心最优性 对欧氏样本的任一当前划分, Ward 链接选择使下一步总 SSE 增量最小的簇对; 任意两个非空簇

⁴⁶ G. N. Lance, W. T. Williams, *A General Theory of Classificatory Sorting Strategies: 1. Hierarchical Systems In The Computer Journal*, 1967, vol. 9, no. 4, pp. 373–380

⁴⁷ D. Müllner, *Modern Hierarchical Agglomerative Clustering Algorithms*, 2011, arXiv: 1109.2378, URL: <https://arxiv.org/abs/1109.2378>

满足

$$\Delta \text{SSE}(A, B) = \frac{|A||B|}{|A| + |B|} \|\mu_A - \mu_B\|_2^2.$$

证明. 令 $a = |A|$ 、 $b = |B|$ ，则合并均值为 $\mu = (a\mu_A + b\mu_B)/(a + b)$ 。由式 (4.4)，合并后的 SSE 等于两簇原有 SSE 加上

$$a\|\mu_A - \mu\|_2^2 + b\|\mu_B - \mu\|_2^2.$$

又有 $\mu_A - \mu = b(\mu_A - \mu_B)/(a + b)$ ，另一项为其相反方向的 a/b 倍。代入后系数为 $(ab^2 + ba^2)/(a + b)^2 = ab/(a + b)$ 。其他簇不变，因此选择最小 Ward 相异度恰好最小化当前总 SSE 增量。 ■

这一结论只比较当前可合并的簇对，不保证截取出的 K 簇划分是 SSE 全局最优，也不保证与 K-means 的解接近。Ward 结果可以作为 K-means 的初始化，此后的重新分配可能继续降低 SSE。

单链接具有另一种解释：对完整加权图求最小生成树，按边权从小到大连接，得到相同的阈值连通结构；等权边下具体二叉树表示可以不同。全链接则选择跨簇最大距离最小的簇对，它对直径的控制不同于 Ward 对总平方误差的控制。两者都不是对整棵树联合求最优。

泛化分析 层次树通常描述训练样本之间的关系。新样本如何插入、抽样扰动是否改变关键分支，需要额外规则或重采样检验；得到一棵确定的树不构成总体稳定性的保证。尤其在多个候选合并的相异度十分接近时，轻微的数据变化就可能改变早期合并，再传递到更高层次。可以对样本重采样，考察关心的群组是否反复出现，而不是仅凭一次树状图的清晰程度判断结构可信。

4.5.1.4 小结

AGNES 提供从细到粗的层级视图，适合需要解释嵌套关系的探索任务。选择链接方式就选择了几何偏好，其中单链接本来就能表达非凸形状。主要限制是距离处理成本和合并不可撤销；后续改进可以压缩数据或改变合并准则，但不能据此宣称消除了所有早期错误。

4.5.2 DIANA（分裂层次聚类）

若关心的是“整个数据应先拆成哪几大块”，可以从树根开始。**分裂分析** (Divisive Analysis, DIANA) 以全部样本为一个簇，逐步分裂不一致程度最高的簇，与 AGNES 构成方向上的对照。它更早显露顶层划分，但顶层一旦选错，也会约束后续结构。

4.5.2.1 模型结构

DIANA 通常用簇直径 $\max_{i,j \in C} \delta(\mathbf{x}_i, \mathbf{x}_j)$ 选择待分裂簇。每次把一个非单点簇拆成两个非空子簇；若展开完整树，恰需 $n - 1$ 次分裂。若只需少数大簇，也可提前停止。

4.5.2.2 参数学习

对含 m 个样本的簇，非平凡无序二分共有 $2^{m-1} - 1$ 种，完整枚举很快变得昂贵。DIANA 用**分裂群** (splinter group) 贪心构造二分：选取对其余样本平均相异度最大的样本作为种子，令其自成集合 S ，其余样本组成 R 。

对每个 $i \in R$ ，在 $|R| > 1$ 时计算

$$a_i = \frac{1}{|R| - 1} \sum_{\substack{j \in R \\ j \neq i}} \delta(\mathbf{x}_i, \mathbf{x}_j), \quad b_i = \frac{1}{|S|} \sum_{j \in S} \delta(\mathbf{x}_i, \mathbf{x}_j).$$

若最大的 $a_i - b_i$ 为正，就把对应样本从 R 移到 S ，再更新这些量；否则结束分裂。这样每一步都选择更接近分裂群的最强候选，而非按任意顺序一次扫描。保留至少一个样本在 R 中，避免产生空子簇。

4.5.2.3 小结

DIANA 用启发式二分替代昂贵的穷举，适合优先查看顶层结构。其结果依赖相异度、种子和平局处理；仅凭分裂是启发式，不能断言它在所有数据上都比 AGNES 不稳定。完整树的成本也取决于距离缓存、分裂形态及更新方式。

4.5.3 模型对比与总结

本小节先比较 AGNES 与 DIANA，再把面向规模、形状或关系输入的层次方法作为代表性扩展。AGNES 不断合并，DIANA 不断分裂，两者都把粒度选择推迟到层次结果形成之后。合并时容易比较局部候选，分裂时则需在大量可能的二分中作出近似选择。是否更适合某个任务，应依据希望保留的层次以及相异度的含义判断。

当数据装不进内存时，可先压缩再聚类。BIRCH 用**聚类特征** (clustering feature, CF) 记录样本数、向量和与平方范数和⁴⁸。这些摘要写为

$$CF(C) = \left(|C|, \sum_{i \in C} \mathbf{x}_i, \sum_{i \in C} \|\mathbf{x}_i\|_2^2 \right).$$

这些量可相加，也可恢复均值和簇内平方误差。CF 树把邻近样本汇入摘要节点，再对叶摘要聚类；在树高和摘要规模受控时，扫描成本近似随 n 线性增长，但最终质量受阈值、插入顺序及摘要损失影响。

⁴⁸ T. Zhang, R. Ramakrishnan, M. Livny, *BIRCH: An Efficient Data Clustering Method for Very Large Databases* In Proceedings of the ACM SIGMOD International Conference on Management of Data, 1996, pp. 103–114

CURE 用多个分散代表点描述每簇⁴⁹。选择代表时，先选离均值较远的点，再逐个选择离已有代表集合较远的点，使代表覆盖簇的不同部分；随后把它们向均值收缩，以减弱孤立点影响。若原代表为 $\mathbf{r}$ 、簇均值为 μ_C ，收缩后的代表可写为

$$\mathbf{r}' = (1 - \alpha)\mathbf{r} + \alpha\mu_C, \quad 0 \leq \alpha \leq 1.$$

两个簇的代表之间的最近距离用于决定合并。 $\alpha = 0$ 保留边缘形状，也更易受极端点影响； α 接近 1 时，代表逐渐退化为中心。CURE 结合抽样与分区降低处理规模，但不能据此给一般完整层次过程统一保证 $O(n \log n)$ 时间。

对类别属性，ROCK 用共同邻居所形成的链接数量替代单纯点间距离，其工作发表于 1999 年⁵⁰。它依然依赖邻居定义，且共享邻居统计会带来额外成本。

Chameleon 在近邻图的初始子簇之上，根据相对互连度与相对相近度决定合并，使评价随簇的内部结构变化。它改进的是合并准则，而非撤销已完成合并的回溯机制⁵¹。

这些改进说明，层次聚类可以兼顾摘要、形状与关系信息，但每一种都有条件。若还需要说明样本可能来自哪一种生成成分，下一节将用概率分布建立这种解释。

4.6 基于概率的聚类

中心距离、密度连通性和图割已经给出了多种分组准则。如果还希望回答“一个新样本来自哪种群体的概率有多大”，就需要显式的概率模型。基于概率的聚类假设样本先选择一个隐含成分，再由该成分的分布生成；聚类于是变成潜在成分变量的后验推断与分布参数估计。

这种解释自然支持软归属、预测密度和模型比较。其前提是所选分布族与任务中的群组含义相符：密度拟合需要的成分数，未必等于业务意义上的类别数。以高斯混合为例，一个复杂形状的群体可能需要多个高斯共同近似。

4.6.1 高斯混合模型 (GMM)

高斯混合模型 (Gaussian Mixture Model, GMM) 为每个成分配置均值和协方差，能够表达不同方向、尺度的椭球形分布。其现代教材形式常与 EM 算法一起介绍，但混合模型的历史远早于这一算法框架⁵²。

Pearson 在 1894 年的研究中，用两个正态分布的混合拟合一组生物测量数据，并通过矩方程估计参数⁵³。关键想法是：观测到的一个总体，可

⁴⁹ S. Guha, R. Rastogi, K. Shim, *CURE: An Efficient Clustering Algorithm for Large Databases* In Proceedings of the ACM SIGMOD International Conference on Management of Data, 1998, pp. 73–84

⁵⁰ S. Guha, R. Rastogi, K. Shim, *ROCK: A Robust Clustering Algorithm for Categorical Attributes* In Proceedings of the 15th International Conference on Data Engineering, 1999, pp. 512–521

⁵¹ G. Karypis, E.-H. Han, V. Kumar, *Chameleon: Hierarchical Clustering Using Dynamic Modeling* In Computer, 1999, vol. 32, no. 8, pp. 68–75

⁵² C. M. Bishop, *Pattern Recognition and Machine Learning*, Springer, 2006, 1st ed.

⁵³ K. Pearson, *Contributions to the Mathematical Theory of Evolution* In Philosophical Transactions of the Royal Society of London. A, 1894, vol. 185, pp. 71–110

能混合了多个未被直接标注的子总体。分布中的多个成分因此可以作为隐含群组的统计表示。

Wolfe 在 1970 年讨论了基于多元混合分析的模式聚类，把这一表示与多维数据的似然估计结合起来⁵⁴。到 1977 年，Dempster、Laird 与 Rubin 将一类含潜变量模型的估计技巧统一为 EM 框架。GMM 提供“样本怎样生成”的模型，EM 提供“看不到潜在成分变量时怎样估计参数”的算法，二者解决的是不同层面的问题。

⁵⁴ J. H. Wolfe, *Pattern Clustering by Multivariate Mixture Analysis In Multivariate Behavioral Research*, 1970, vol. 5, no. 3, pp. 329–350

相对于 K-means，GMM 的变化不只是把硬簇分配改为软归属。协方差参与衡量方向和尺度，混合权重参与描述成分比例；一个样本是否接近某个均值，也要结合这些参数判断。

4.6.1.1 模型结构

与第3.4.3节的 GDA 相比，两者都用高斯密度描述输入，但 GDA 的类别标签已经观测，可以按类直接估计；GMM 的成分归属不可观测，需要作为潜在成分变量推断。具体而言，先按权重 $\pi_k \geq 0$ 、 $\sum_k \pi_k = 1$ 抽取潜在成分变量 $z_i \in \{1, \dots, K\}$ ，再从 $\mathcal{N}(\mu_{z_i}, \Sigma_{z_i})$ 抽取样本。要求 $\Sigma_k > 0$ ，边际密度为

$$p(\mathbf{x}; \theta) = \sum_{k=1}^K \pi_k \mathcal{N}(\mathbf{x}; \mu_k, \Sigma_k), \quad (4.20)$$

其中 θ 汇集权重、均值与协方差。独立同分布样本的对数似然为

$$\ell(\theta) = \sum_{i=1}^n \log \left[\sum_{k=1}^K \pi_k \mathcal{N}(\mathbf{x}_i; \mu_k, \Sigma_k) \right].$$

求和藏在对数内，使每个成分的参数无法独立优化。

给定参数后，贝叶斯公式给出**责任度** (responsibility)，即当前模型认为样本由某成分产生的后验概率：

$$\gamma_{i,k} = \frac{\pi_k \mathcal{N}(\mathbf{x}_i; \mu_k, \Sigma_k)}{\sum_{j=1}^K \pi_j \mathcal{N}(\mathbf{x}_i; \mu_j, \Sigma_j)}. \quad (4.21)$$

每行责任度和为 1，构成软划分；需要硬簇分配时取 $\arg \max_k \gamma_{i,k}$ 。这一概率依赖当前生成模型，不是独立于模型假设的“真实类别置信度”。

图 4.9 区分了混合密度与成分归属：上图的两条加权成分密度相加，得到观测的总密度；下图则把各成分的贡献除以这个总密度，得到 $\gamma_k(\mathbf{x}) = p(z = k | \mathbf{x}; \theta)$ 。在对称位置 $\mathbf{x} = 0$ ，两者各占一半；沿横轴移动时，后验连续变化。两个成分的存在也不要求混合密度具有两个分离的峰。




图 4.9 两成分 GMM 的密度与软归属。设 $\pi_1 = \pi_2 = 1/2$ 、 $\mu_1 = -1$ 、 $\mu_2 = 1$ ，两个方差均为 1， $p_k(x)$ 表示第 k 个高斯密度。上图展示加权成分密度及其和，下图展示同一观测值对应的后验；颜色与线型在两图中保持一致。

4.6.1.2 参数学习

期望最大化 (Expectation-Maximization, EM) 交替估计潜在成分变量的分布和优化参数，Dempster、Laird 与 Rubin 将这一原则统一为一般框架⁵⁵。E 步用当前参数 $\theta^{(t)}$ 计算式 (4.21)；M 步固定这些责任度，最大化完全数据对数似然的期望。潜在成分变量不再藏在对数的求和中，而是通过 E 步给出的分布参与加权。

忽略与参数无关的常数，M 步目标为

$$Q(\theta | \theta^{(t)}) = \sum_{i,k} \gamma_{i,k}^{(t)} \left[\log \pi_k - \frac{1}{2} \log \det \Sigma_k - \frac{1}{2} (\mathbf{x}_i - \boldsymbol{\mu}_k)^\top \Sigma_k^{-1} (\mathbf{x}_i - \boldsymbol{\mu}_k) \right]. \quad (4.22)$$

记有效样本量 $n_k^{(t)} = \sum_i \gamma_{i,k}^{(t)}$ 。权重优化加入约束 $\sum_k \pi_k = 1$ 的拉格朗日乘子，驻点满足 $n_k^{(t)}/\pi_k = \lambda$ ；求和得到 $\lambda = n$ ，所以

$$\pi_k^{(t+1)} = \frac{n_k^{(t)}}{n}, \quad \boldsymbol{\mu}_k^{(t+1)} = \frac{\sum_i \gamma_{i,k}^{(t)} \mathbf{x}_i}{n_k^{(t)}}. \quad (4.23)$$

均值公式来自 Q 对 $\boldsymbol{\mu}_k$ 的梯度为零：公共正定因子 Σ_k^{-1} 消去，剩下加权残

⁵⁵ A. P. Dempster, N. M. Laird, D. B. Rubin, *Maximum Likelihood from Incomplete Data via the EM Algorithm* In Journal of the Royal Statistical Society: Series B (Methodological), 1977, vol. 39, no. 1, pp. 1–38

差和为零。

再令精度矩阵 $\mathbf{\Lambda}_k = \mathbf{\Sigma}_k^{-1}$ ，加权散布为

$$\mathbf{S}_k = \sum_i \gamma_{i,k}^{(t)} (\mathbf{x}_i - \boldsymbol{\mu}_k^{(t+1)}) (\mathbf{x}_i - \boldsymbol{\mu}_k^{(t+1)})^\top.$$

相关目标为 $\frac{1}{2} [n_k^{(t)} \log \det \mathbf{\Lambda}_k - \text{tr}(\mathbf{\Lambda}_k \mathbf{S}_k)]$ 。求导得 $n_k^{(t)} \mathbf{\Lambda}_k^{-1} - \mathbf{S}_k = \mathbf{0}$ ，于是

$$\mathbf{\Sigma}_k^{(t+1)} = \frac{\mathbf{S}_k}{n_k^{(t)}}. \quad (4.24)$$

这些公式要求有效样本量为正；无约束协方差更新还要求加权散布正定，否则不存在正定域内的有限最优解。

代码 4.6 用对数概率计算责任度，避免直接相乘小概率造成下溢。它把协方差特征值限制为不小于 ϵ ，这是固定约束 $\mathbf{\Sigma}_k \geq \epsilon \mathbf{I}$ 下的 M 步；它不同于不加说明地每轮给协方差加上一个常数矩阵。

代码 4.6 带协方差下界的 GMM-EM

```
1 import numpy as np
2 from scipy.special import logsumexp
3 from scipy.stats import multivariate_normal
4
5 def gmm_em(X, K, max_iter=100, tol=1e-5, eps=1e-6):
6     X = np.asarray(X, dtype=float)
7     n, d = X.shape
8     if eps <= 0:
9         raise ValueError("eps must be positive")
10    _, mu = kmeans(X, K)
11    pi = np.full(K, 1.0 / K)
12    cov = np.repeat((max(1., eps) * np.eye(d))[None], K,
13                    axis=0)
14    def e_step():
15        log_p = np.column_stack([
16            np.log(pi[k]) + multivariate_normal.logpdf(
17                X, mean=mu[k], cov=cov[k])
18            for k in range(K)])
19        normalizer = logsumexp(log_p, axis=1)
20        gamma = np.exp(log_p - normalizer[:, None])
21        return gamma, normalizer.sum()
22    gamma, ll = e_step()
23    for _ in range(max_iter):
24        nk = gamma.sum(0)
25        if (nk <= 0).any():
```

```

25         raise ValueError("numerically empty component")
26     pi = nk / n
27     mu = (gamma.T @ X) / nk[:, None]
28     for k in range(K):
29         diff = X - mu[k]
30         S = (diff * gamma[:, k, None]).T @ diff / nk[k]
31         values, vectors = np.linalg.eigh(S)
32         cov[k] = (vectors * np.maximum(values, eps)) @
vectors.T
33     gamma, new_ll = e_step()
34     if abs(new_ll - ll) <= tol * (1 + abs(ll)):
35         break
36     ll = new_ll
37     return pi, mu, cov, gamma

```

该实现调用前文的 K-means，以其中心初始化，返回的责任度由最终参数重新计算。协方差特征值截断之所以是上述受限 M 步的解，是因为最优协方差与加权散布共享特征向量，每个特征值分别最小化 $\log s + \lambda/s$ ，在 $s \geq \epsilon$ 上得到 $s = \max\{\lambda, \epsilon\}$ 。实际还应监测似然下降、重启质量和数值上近空的成分。

容量较大时可用完整协方差；数据不足时可限制为对角、球形或所有成分共享协方差。完整协方差的一轮成本约为 $O(nKd^2 + Kd^3)$ ，其中立方项来自各成分的矩阵分解；对角形式可把主要计算降到 $O(nKd)$ 。K-means++、多次重启和由初始划分估计协方差，都有助于选择合理起点，但不保证全局最优。

4.6.1.3 理论分析

收敛性分析 EM 的单调性来自在旧参数处贴合的似然下界。它不要求把观测似然直接求到最优，却要求 M 步至少提高相应辅助目标。

定理 4.7 EM 的似然单调性 E 步取当前精确后验，M 步满足 $Q(\theta^{(t+1)} | \theta^{(t)}) \geq Q(\theta^{(t)} | \theta^{(t)})$ 。在相关概率与期望有限、支持条件允许下，则 $\ell(\theta^{(t+1)}) \geq \ell(\theta^{(t)})$ 。

证明. 对每个样本任取潜变量分布 q_i 。由对数的凹性，

$$\begin{aligned}
 \log p(\mathbf{x}_i; \theta) &= \log \sum_k q_i(k) \frac{p(\mathbf{x}_i, z_i = k; \theta)}{q_i(k)} \\
 &\geq \sum_k q_i(k) \log \frac{p(\mathbf{x}_i, z_i = k; \theta)}{q_i(k)}.
 \end{aligned}$$

对样本求和，把右边记为 $\mathcal{L}(q, \theta)$ 。它与似然之差恰为

$$\ell(\theta) - \mathcal{L}(q, \theta) = \sum_i \text{KL}(q_i \| p(z_i | \mathbf{x}_i; \theta)) \geq 0.$$

E 步令 $q_i^{(t)}$ 等于旧参数的后验，因此 $\mathcal{L}(q^{(t)}, \theta^{(t)}) = \ell(\theta^{(t)})$ 。固定 $q^{(t)}$ 后，下界与 Q 仅相差不含参数的熵项，M 步遂给出

$$\begin{aligned} \ell(\theta^{(t+1)}) &\geq \mathcal{L}(q^{(t)}, \theta^{(t+1)}) \\ &\geq \mathcal{L}(q^{(t)}, \theta^{(t)}) = \ell(\theta^{(t)}). \end{aligned}$$

这就证明了单调性。 ■

关于 EM 参数收敛的充分条件，可参见 Wu 的分析⁵⁶。若参数域保证似然有上界，单调性进一步给出似然值收敛；参数序列收敛到驻点则需要连续性、紧性或其他正则条件。EM 可以趋近局部极大值，也可能停在鞍点，不能把单调性直接表述为“必然收敛到最优模型”。

⁵⁶ C. F. J. Wu, *On the Convergence Properties of the EM Algorithm* In *The Annals of Statistics*, 1983, vol. 11, no. 1, pp. 95–103

当 $K \geq 2$ ，且模型中存在一个可塌缩的正权重成分，其余正权重成分仍使其他样本的混合密度保持正值时，无约束 GMM 的似然没有上界。令可塌缩成分的均值等于某个样本，协方差为 $\sigma^2 \mathbf{I}$ ；当 $\sigma \rightarrow 0$ 时，该样本处的密度按 σ^{-d} 增长，而其他样本仍由其余成分覆盖，因此总对数似然可以无界增加。若 $K = 1$ 且样本经验散布矩阵正定，单高斯的最大似然有限；若经验散布矩阵奇异，协方差仍可能在数据未占据的方向趋近边界并导致似然退化。协方差下界、适当先验或惩罚可以阻止这类塌缩，但它们各自改变了优化问题。

潜在成分编号的置换不改变混合密度；当成分彼此不同且权重为正时，一个解通常对应 $K!$ 个等价标号。这与不同拟合质量的局部极值是两类问题。

泛化分析 GMM 可以用新样本的平均对数似然评价预测密度，但训练似然提高不保证留出数据上的表现提高。选择成分数和协方差形式时，需要权衡拟合误差与参数估计误差；使用信息准则选择 K 时，也须比较相同约束下的拟合。完整协方差模型的参数数目为

$$m_K = (K - 1) + Kd + \frac{Kd(d + 1)}{2},$$

常用准则为

$$\text{BIC}(K) = -2\ell(\hat{\theta}_K) + m_K \log n, \quad \text{AIC}(K) = -2\ell(\hat{\theta}_K) + 2m_K. \quad (4.25)$$

选择较小者是在拟合与复杂度之间取舍。BIC 源于模型证据的渐近近似；有限混合存在零权重边界、不可辨识和奇异性，不能直接套用所有正则模

型的推导,也不能把 BIC 称为无条件一致的证据估计。混合阶数的一致性需要专门条件⁵⁷。

即使正确估计了混合阶数,也只说明分布拟合所需的成分数。把它解释为语义类别数,还需说明一个类别是否对应一个成分。

4.6.1.4 小结

GMM 提供软后验、协方差结构和预测密度,适合需要概率语义的聚类、语音建模或异常评分。它的边界包括分布失配、似然奇异性及局部优化;使用多个高斯可以逼近复杂密度,却未必使每个成分都成为独立可解释的类别。

4.6.2 模型对比与总结

本小节先比较 GMM 与 K-means 的目标和输出,再把成分分布或成分数先验的变化作为代表性扩展。GMM 与 K-means 的联系可由小方差极限看清。固定均匀权重 $\pi_k = 1/K$ 和共享球形协方差 $\Sigma_k = \sigma^2 \mathbf{I}$, 则

$$\gamma_{i,k} = \frac{\exp(-\|\mathbf{x}_i - \boldsymbol{\mu}_k\|_2^2 / (2\sigma^2))}{\sum_j \exp(-\|\mathbf{x}_i - \boldsymbol{\mu}_j\|_2^2 / (2\sigma^2))}.$$

若 $\mathbf{x}_i$ 的最近中心唯一为 k^* , 则对任意 $j \neq k^*$, 距离平方差为正, 相应指数比随 $\sigma^2 \rightarrow 0$ 趋零, 故 $\gamma_{i,k^*} \rightarrow 1$ 。M 步的均值更新因此退化为 Lloyd 更新; 平局时责任度可分散在多个最近中心, 不能直接得到唯一硬簇分配。

从目标看, 去掉仅依赖 σ 的常数后, $-2\sigma^2 \ell$ 趋向 $\sum_i \min_k \|\mathbf{x}_i - \boldsymbol{\mu}_k\|_2^2$ 。这个联系要求共享固定方差随极限缩小, 不能把自由更新各簇协方差的普通 GMM 直接等同于 K-means。FCM 也使用软归属, 但其隶属度来自模糊目标, 并非一般 GMM 后验。

更换成分分布即可适配其他数据: 伯努利混合适合二值特征, 多项式混合适合计数向量; 重尾的 t 混合可减轻离群观测对均值和尺度估计的影响, 其代价是引入额外的尺度或自由度估计⁵⁸。

狄利克雷过程混合 (Dirichlet process mixture, DPM) 把先验放在随机混合分布上, 使潜在成分数不再预先固定; Neal 研究了这类模型的 MCMC 推断⁵⁹。也可采用变分方法近似后验。浓度参数影响新成分的倾向; “不固定 K ” 并不意味着无需先验选择, 也不自动保证恢复真实有限类别数。

概率路线的优势是把分组、密度预测和模型比较放在同一框架中。是否采用它, 应取决于所需概率语义和分布假设, 而非认为其他几何或密度方法都没有统计解释。

⁵⁷ C. Keribin, *Consistent Estimation of the Order of Mixture Models* In *Sankhyā: The Indian Journal of Statistics, Series A*, 2000, vol. 62, no. 1, pp. 49–66

⁵⁸ D. Peel, G. J. McLachlan, *Robust Mixture Modelling Using the t Distribution* In *Statistics and Computing*, 2000, vol. 10, no. 4, pp. 339–348

⁵⁹ R. M. Neal, *Markov Chain Sampling Methods for Dirichlet Process Mixture Models* In *Journal of Computational and Graphical Statistics*, 2000, vol. 9, no. 2, pp. 249–265

4.7 基于集成的聚类

当不同初始化、样本扰动、表示或算法得到多个候选划分时，**共识聚类** (consensus clustering) 提供一种代表性扩展：对每对样本统计它们在多少个候选结果中共簇，形成共关联矩阵，再聚类该矩阵或对应图以得到共识划分⁶⁰。它可把“哪些样本反复共簇”变成稳定性诊断。只有对象集固定，例如对同一批对象重复测量或重复运行时，才能直接比较共关联矩阵；样本扰动改变对象集时，应只比较共同对象，或先冻结新样本分配规则，再把候选划分应用于同一批评价对象，具体协议见后文表4.3。若在没有共同对象的独立样本上检验可复制性，应预先规定候选生成方式，并比较簇轮廓、外部关联或用途指标，不能直接比较共关联矩阵。在同一数据上反复筛选再取共识，也不能制造新的外部证据。少数但有意义的结构还可能被多数划分淹没，因此应同时报告共关联强度、候选来源和与无聚类基线的比较。

4.8 半监督聚类

没有完整类别标签集，并不意味着领域知识为空。专家可能知道两份记录来自同一对象，或两个样本不应属于同类；也可能只标注了少量典型种子。**半监督聚类** (semi-supervised clustering) 把这些信号纳入以未标注样本为主体的分组过程。

第3.6节的半监督分类利用未标注输入改进预先定义类别的预测，本节则用少量类别标签或关系先验共同决定分组。两者都改变可用监督信息，却保留不同的任务目标。

实例级信号常写为**必连约束** (must-link) 和**勿连约束** (cannot-link)：前者要求两个样本同簇，后者要求异簇。记其索引对集合为 M 和 B ，以免与簇 C_k 或划分 $\mathcal{P}$ 混淆。信号既可作为硬约束，也可带权违反；少量关系判断是否比逐点类别标签更容易获取，取决于实际标注任务。

本节保持聚类的目标：用几何结构和先验共同决定分组，而非假定所有类别已由带类别标签的样本充分规定。约束质量、覆盖范围及与几何假设是否冲突，都会影响最终收益。

4.8.1 COP-K-means

如果必须满足全部关系约束，可以在分配时排除违法簇标记。Wagstaff 等在 2001 年提出的 COP-K-means 采用这种硬约束方式⁶¹。算法把 K-means 的最近中心选择限制在当前可行选项内。

⁶⁰ A. Strehl, J. Ghosh, *Cluster Ensembles—A Knowledge Reuse Framework for Combining Multiple Partitions* In Journal of Machine Learning Research, 2002, vol. 3, pp. 583–617

⁶¹ K. Wagstaff, C. Cardie, S. Rogers, S. Schroedl, *Constrained K-Means Clustering with Background Knowledge* In Proceedings of the Eighteenth International Conference on Machine Learning, 2001, pp. 577–584

4.8.1.1 模型结构

目标仍为式 (4.1), 可行域增加

$$c_i = c_j \quad ((i, j) \in M), \quad c_i \neq c_j \quad ((i, j) \in B). \quad (4.26)$$

must-link 的传递闭包把样本分成**约束块** (chunklet), 同一块必须整体分配。若 cannot-link 的两端落在同一块内, 约束立即矛盾; 但不存在这种矛盾还不足以保证给定 K 下可行。

把每个约束块当作顶点、cannot-link 当作边, 块的簇分配实际上是该图的 K 着色。例如三个两两 cannot-link 的块不能放进两个簇, 即使没有任何 must-link 冲突。块级 SSE 可分解为块内常数加上“块大小乘以块均值到中心的平方距离”, 因此整体分配也能利用摘要。

4.8.1.2 参数学习

COP-K-means 按某个顺序处理样本或约束块, 对候选簇按距离排序, 接受第一个与已固定分配相容的簇。若没有候选, 就报告本次贪心分配失败; 更新步则对每个非空簇取均值。

算法 4.2 COP-K-means 的约束块分配

输入: must-link 闭包、块间 cannot-link、当前中心

输出: 本轮可行分配, 或本轮贪心失败

- 1: 清空本轮簇分配, 选定约束块访问顺序
- 2: **for** 每个约束块 U **do**
- 3: 按 $\sum_{i \in U} \|\mathbf{x}_i - \boldsymbol{\mu}_k\|_2^2$ 排序候选簇
- 4: 选择不与已分配邻块冲突的最近候选
- 5: **if** 候选不存在 **then**
- 6: 返回本轮失败
- 7: **end if**
- 8: 把 U 的全部样本分给所选簇
- 9: **end for**

本轮失败不是不可行性证明。考虑 cannot-link 图为路径 $a - b - c - d$, 取 $K = 2$ 。若顺序为 a, d, b, c , 且前两块都优先选择簇 1, 那么 b 被迫选择簇 2, 轮到 c 时两簇都被相邻块占用, 贪心失败; 但划分 $\{a, c\}$ 、 $\{b, d\}$ 完全可行。

此外, 重新按顺序贪心分配并没有精确最小化受约束目标, 不能直接继承 Lloyd 的单调性和有限停止定理。若要保证下降, 可从已有可行解出发, 仅接受降低目标且保持可行的块移动; 或用精确受约束分配子问题配合均值更新。前者可能更早停在局部状态, 后者则需承担组合优化成本。普通 COP 实现宜设置上限、记录失败并重启或回溯。

4.8.1.3 小结

COP-K-means 的好处是约束含义明确, 成功输出可以逐项检查是否满足关系。代价是约束冲突、给定 K 下不可行以及贪心顺序失败都必须处理。若先验允许出错, PCK-means 在 SSE 上增加

$$\sum_{(i,j) \in M} w_{i,j}^M \mathbb{1}\{c_i \neq c_j\} + \sum_{(i,j) \in B} w_{i,j}^B \mathbb{1}\{c_i = c_j\},$$

以软惩罚权衡几何和约束。有限权重不保证零违反, 但避免因单条错误关系直接拒绝整个问题。

4.8.2 Seeded / Constrained K-means

若已知的是少量样本的类别名称, 可以直接用它们确定初始中心或固定归属。Basu、Banerjee 与 Mooney 在 2002 年研究了 Seeded K-means 与类别标签约束的 Constrained K-means⁶²。后者与第 4.1.1.5 节的同名容量约束方法含义不同: 本节锁定种子的类别标签, 容量方法限制各簇样本数。

⁶² S. Basu, A. Banerjee, R. J. Mooney, *Semi-Supervised Clustering by Seeding* In Proceedings of the Nineteenth International Conference on Machine Learning, 2002, pp. 27–34

4.8.2.1 模型结构

设种子索引集合为 S , 类别标签为 $\ell_s \in \{1, \dots, K\}$, 并记 $S_k = \{s \in S : \ell_s = k\}$ 。当每类都有种子时, 初始化为

$$\mu_k^{(0)} = \frac{1}{|S_k|} \sum_{s \in S_k} \mathbf{x}_s.$$

缺少种子的簇需另外初始化。Seeded 版本只在初始化时使用类别标签, 之后种子可以移动; Constrained 版本始终要求 $c_s = \ell_s$, 把种子类别标签作为硬事实。二者都优化同一个平方误差目标, 只是初始化与可行域不同。

4.8.2.2 参数学习

Seeded 版本随后直接运行 Lloyd。Constrained 版本在分配步冻结种子, 其余样本独立选择最近中心; 更新中心时同时计入种子和非种子。由于冻结限制彼此不耦合, 逐点分配仍是固定中心下的精确最优解, 因此可沿用定理 4.1 的下降论证与平局条件。每簇都有固定种子时, 还自然避免了空簇。

种子可以帮助消除初始化歧义, 却未必代表整个群组。若种子类别标签可能错, 允许其移动减少了永久锁定错误的风险; 若类别标签可靠而未标注数据几何有歧义, 固定类别标签更能保留监督信息。效果随种子代表性、比例和错误类型变化, 不能把少量种子在某些实验中的收益推广为统一保证。

4.8.2.3 小结

种子方法以很小的算法改动引入类别标签信息，适合已知类别名称且每类有少量代表样本的情况。它们仍依赖欧氏距离和均值表示；要表达“哪些方向更重要”，需要进一步改变度量本身。

4.8.3 MPCK-means

如果重要特征与无关特征混在一起，约束即使改变了簇分配，也未必能改变下一轮的距离判断。Bilenko、Basu 与 Mooney 在 2004 年提出的 MPCK-means (Metric Pairwise Constrained K-means) 同时优化分配和簇相关度量，使关系约束既影响簇分配，也影响空间中的方向与尺度⁶³。

从 COP-K-means 到种子方法，再到 MPCK-means，弱监督逐步进入了不同的计算环节：关系约束限制分配，种子类别标签确定初始位置或固定成员，成对约束还可以参与塑造距离。这些路线并未相互取代，而是对不同形式与可信程度的先验。

⁶³ M. Bilenko, S. Basu, R. J. Mooney, *Integrating Constraints and Metric Learning in Semi-Supervised Clustering* In Proceedings of the Twenty-First International Conference on Machine Learning, 2004, pp. 81–88

4.8.3.1 模型结构

为簇 k 配置正定矩阵 $\mathbf{A}_k > 0$ ，定义平方 Mahalanobis 距离

$$d_{\mathbf{A}_k}^2(\mathbf{x}, \mathbf{y}) = (\mathbf{x} - \mathbf{y})^\top \mathbf{A}_k (\mathbf{x} - \mathbf{y}).$$

正定性既保证非退化距离，也使 $\log \det \mathbf{A}_k$ 有定义。可以把这种距离看作先做坐标变换 $\tilde{\mathbf{x}} = \mathbf{A}_k^{1/2} \mathbf{x}$ ，再计算欧氏距离。图 4.10 给出了一个固定变换的例子：压缩水平方向、拉伸竖直方向后，must-link 对变近，而 cannot-link 对变远。实际 MPCK-means 需要根据全部样本与约束优化 $\mathbf{A}_k$ ，并非预先知道图中的变换。




图 4.10 度量如何改变成对关系的几何表达。四点为 $\mathbf{u} = (-2, 0.5)$ 、 $\mathbf{v} = (2, 0.5)$ 、 $\mathbf{w} = (-2, -0.5)$ 、 $\mathbf{z} = (2, -0.5)$ 。实线连接 must-link 对，虚线连接 cannot-link 对。这里人为设定 $\mathbf{A} = \text{diag}(1/16, 4)$ ；右图的距离等于左图的 Mahalanobis 距离，不表示一次真实训练的结果。

记在该度量下全数据的最大距离平方为

$$D_k = \max_{p,q \in \{1,\dots,n\}} d_{\mathbf{A}_k}^2(\mathbf{x}_p, \mathbf{x}_q).$$

对违反 must-link 的样本对，惩罚同时作用于两端所属簇；对违反 cannot-link 的样本对，惩罚其相对于本簇度量下最远样本对的接近程度。具体写为

$$\begin{aligned} f_M(i, j) &= \frac{1}{2} \left[d_{\mathbf{A}_{c_i}}^2(\mathbf{x}_i, \mathbf{x}_j) + d_{\mathbf{A}_{c_j}}^2(\mathbf{x}_i, \mathbf{x}_j) \right] \mathbb{1}\{c_i \neq c_j\}, \\ f_B(i, j) &= \left[D_{c_i} - d_{\mathbf{A}_{c_i}}^2(\mathbf{x}_i, \mathbf{x}_j) \right] \mathbb{1}\{c_i = c_j\}. \end{aligned} \quad (4.27)$$

因此 cannot-link 惩罚非负，must-link 惩罚也不因交换样本对的书写顺序而改变。总目标为

$$\begin{aligned} J &= \sum_{k=1}^K \sum_{i \in C_k} \left[d_{\mathbf{A}_k}^2(\mathbf{x}_i, \boldsymbol{\mu}_k) - \log \det \mathbf{A}_k \right] \\ &\quad + \sum_{(i,j) \in M} w_{i,j}^M f_M(i, j) + \sum_{(i,j) \in B} w_{i,j}^B f_B(i, j). \end{aligned} \quad (4.28)$$

权重均非负，每个无序约束对只计一次。负对数行列式阻止特征值趋零，但不能单独阻止矩阵某些方向无限放大；数据退化时仍需约束或正则。

4.8.3.2 参数学习

固定中心和度量，逐个检查样本簇分配的所有候选，计算其涉及的几何项、行列式项和全部关系惩罚，只接受不增加整体目标的变更。由于关系耦合样本，不能仅按到中心的 Mahalanobis 距离排序就声称完成了目标最小化。

固定分配和度量时，约束项不含中心。对中心求导给出

$$2\mathbf{A}_k \sum_{i \in C_k} (\boldsymbol{\mu}_k - \mathbf{x}_i) = \mathbf{0}, \quad \boldsymbol{\mu}_k = \frac{1}{|C_k|} \sum_{i \in C_k} \mathbf{x}_i.$$

所以这里仍是普通簇内均值，而不是对各样本施加不同权重的均值；同一簇共用的 $\mathbf{A}_k$ 会消去。

度量步可借助散布矩阵理解。令 $\mathbf{S}_k = \sum_{i \in C_k} (\mathbf{x}_i - \boldsymbol{\mu}_k)(\mathbf{x}_i - \boldsymbol{\mu}_k)^\top$ 。在固定当前最远样本对、且该样本对在更新后仍保持活跃的一个分支上，约束项写成 $\text{tr}(\mathbf{A}_k \mathbf{P}_k)$ ，其中 $\mathbf{P}_k$ 汇总违反 must-link 的半权重差分外积，以及违反 cannot-link 的“最远对外积减约束对外积”。于是子目标为

$$\text{tr}(\mathbf{A}_k(\mathbf{S}_k + \mathbf{P}_k)) - |C_k| \log \det \mathbf{A}_k.$$

若 $\mathbf{S}_k + \mathbf{P}_k > 0$ 且 $|C_k| > 0$, 其无约束驻点为

$$\mathbf{A}_k = |C_k|(\mathbf{S}_k + \mathbf{P}_k)^{-1}. \quad (4.29)$$

这不是无需检查的通用更新: 散布调整项未必正定, 更新还可能改变最大距离对应的样本对。

保留 D_k 对 $\mathbf{A}_k$ 的真实依赖时, 它是有限个线性函数的最大值, 故固定分配和中心的度量问题是凸的, 但通常分段光滑。可在 $\alpha \mathbf{I} \leq \mathbf{A}_k \leq \beta \mathbf{I}$, $0 < \alpha < \beta$ 的固定域上求解, 或使用保持正定且实际下降的优化步骤。对角度量进一步减少参数与矩阵计算。

若各步确实使同一个有下界的目标不减, 只能立即推出目标值收敛; 连续度量参数的变化并不受有限簇分配数限制, 所以不能推出有限轮停止。实践中以目标改进和参数变化的容差终止, 还需单独处理空簇。

4.8.3.3 小结

MPCK-means 把约束用于调整几何, 而非只修正分配。这个方向与 ITML、LMNN 等度量学习方法相关, 但它们的损失、约束及训练目标不同, 不能视为同一算法的简单改名。每簇完整度量含 $d(d+1)/2$ 个参数, 少量约束或高维数据下容易估计不足; 共享或对角度量是降低容量的常见办法。

4.8.4 模型对比与总结

本小节先比较关系约束、种子和度量学习怎样改变 K-means, 再把先验进入图或共享度量的方式作为代表性扩展。COP-K-means 适合必须满足的实例关系, Seeded 与类别标签约束 K-means 适合带类别名称的种子, MPCK-means 适合希望从关系中学习几何的任务。有限惩罚权重允许违反约束, 硬约束则可能无解; 两类语义应在训练前明确。更多参数不必然更充分地利用监督, 覆盖不足时也可能放大标注误差。

先验也可加入谱聚类。Kamvar、Klein 与 Manning 的 Spectral Learning 研究了将监督信息纳入谱表示; 一种直接做法是提高 must-link 边权、降低 cannot-link 边权, 再对修改后的非负对称图求谱表示⁶⁴。

这种改图方式不会强制最终簇分配满足关系: 删除一条 cannot-link 边后, 两端仍可能通过其他强边进入同一簇。修改后的图仍可用相应拉普拉斯理论分析, 但原图的谱间隙、连接结构和统计假设已经改变, 不能说全部理论保证原样保留。关系传播还能把局部信号扩展到邻居, 也可能扩散错误约束, 须与传播假设一起评价。

Xing 等通过相似与不相似样本关系学习 Mahalanobis 度量⁶⁵。这是先单独学习共享度量、再交给聚类算法的解耦方式。这样可以复用监督得到的几何结构, 但共享度量仍假设所有簇使用同一种空间变换, 后续算法也须

⁶⁴ S. D. Kamvar, D. Klein, C. D. Manning, *Spectral Learning* In Proceedings of the Eighteenth International Joint Conference on Artificial Intelligence, 2003, pp. 561–566

⁶⁵ E. P. Xing, A. Y. Ng, M. I. Jordan, S. Russell, *Distance Metric Learning with Application to Clustering with Side-Information* In Advances in Neural Information Processing Systems, 2003, pp. 521–528

与该度量兼容。

半监督聚类的收益取决于信号是否回答了模型原本无法区分的问题。应同时报告几何目标、约束违反情况，以及独立参考标签或下游任务上的效果；用于训练的同一组关系满足得更好，不足以证明聚类具有更好的泛化。

4.9 模型选择与评价

4.9.1 方法比较

原型方法比较样本与代表的相异度，邻域和图方法从局部连通关系形成群组，网格与子空间方法改变比较单位，层次方法保留多个粒度，概率方法解释软归属，集成则汇总多份分组。表4.2对照这些簇判据及输出条件；HDBSCAN 等方法可以同时涉及邻域与层次。

代表方法	簇判据	输出粒度	表示或相异度	优化或推断机制	监督信息
K-means、K-medoids	到原型的总相异度	给定 K 的平坦硬划分	数值向量上的平方距离；一般对象相异度	交替更新；代表交换	无
DBSCAN、OPTICS、HDBSCAN、Mean Shift	密度连通或模态吸引域	噪声、排序、层次或模态簇	邻域距离或核密度	区域扩展、排序、树压缩或模态搜索	无
谱聚类、AP、Louvain	图割、代表支持或模块度	平坦划分；簇数可显式或间接控制	原生图或由相似度构造的加权图	特征松弛、消息传递或局部移动	无
STING、CLIQUE、投影聚类	密集单元或低维紧凑性	区域、重叠子空间或硬划分	网格、坐标子集或学习的投影	摘要查询、候选搜索或代表迭代	无
AGNES、DIANA	链接或分裂准则	嵌套层次，事后截取	点或簇间相异度	贪心合并或启发式分裂	无
GMM、DPM	生成成分及其后验	平坦软归属；成分数固定或随机	数值向量及指定分布族	EM、MCMC 或变分推断	先验不等同于类别标签
共识聚类	多份分组的共同结构	通常为平坦划分	共簇关系或超图	共识函数、图划分等	依赖成员所用信息
COP、Seeded、MPCK-means	基础簇判据加关系或种子约束	通常为平坦硬划分	原始或学习的度量、约束图	受限分配、初始化或度量学习	成对关系、种子或少量类别标签

表 4.2 聚类方法的属性导航。每行登记代表方法在五项属性上的基本设定，不把各主体节解释成互斥类别；方法的具体变体可能改变其中一项或多项。

4.9.2 评价与选择

表示与相异度 比较模型以前，还需要固定输入的含义。变量类型、尺度、相异度和邻接关系共同规定了哪些对象相近。业务或测量协议在数据外预

定尺度时，无须从样本估计；也可以用样本估计的尺度作标准化，但这会重新分配各维对距离的影响，不能机械地用于所有任务。类别变量通常比较取值是否相同，序数变量还需说明等级间距是否可比。对于数值与类别并存的客户记录，可以先为每个变量定义落在可比范围内的相异度，再按预先说明的权重汇总；Gower 系数给出了这一经典构造⁶⁶。Gower 规则按每个样本对执行，只汇总该样本对共同可观测的变量，并按相应权重归一化。若标准化尺度、插补参数、变量范围或权重需要根据数据确定，则只在后文所称的发现数据上估计，冻结后再应用于验证数据。

相异度不一定满足三角不等式；依赖度量性质的索引或近似算法须另行检查条件。构图时还要固定有向近邻的对称化、边权缩放与孤立点处理，再比较图目标。距离、表示与构图规则的改变，都可能改变“同一簇”的含义。

发现与验证 判断算法行为时，需要区分算法是否停止、目标值是否收敛、参数是否收敛，以及分组能否代表训练集之外的结构。前三项属于计算或优化性质，不能直接回答分组是否有用。为使后一问题可执行，先把数据分成**发现数据**（discovery data）和**验证数据**（validation data）：发现数据用于估计表示、尺度、相异度参数，拟合候选聚类并选择簇数或其他超参数；在查看验证结果之前，冻结候选方法、簇匹配规则、指标和用途判断。验证数据可以是预先留出的同源样本，也可以是独立收集的数据；若数据有时间、地点或个体相关性，应按未来使用单位划分，而不是随机打散泄漏结构。Ullmann、Hennig 与 Boulesteix 对使用验证数据复核聚类结果的方式给出了系统框架⁶⁷。

表4.3依次列出训练目标、稳定性、外部标签、零模型、留出证据和下游效用。训练目标、稳定性和零模型可以在发现数据内部帮助诊断与选择；若外部标签承担最终语义验证，就不能再据此调参。留出证据与下游效用也应在规则冻结后检验样本外结论。若候选很多，还需要在发现数据内部做嵌套划分或交叉验证，不能反复查看最终验证数据。稳定性不能作为无条件的簇数选择或语义正确性判据，它还会受目标唯一性与数据对称性影响⁶⁸。零模型也必须匹配待检验问题；Gap Statistic 以参考分布下的簇内离差为比较对象，只是这种检验的一种实现⁶⁹。要把模拟结果解释为校准后的零模型证据，必须在每份模拟数据上重跑与观测数据相同的完整管线，包括预处理、拟合、候选搜索和选择规则；未重跑完整管线时，只能称为探索性基线。

内部指标可补充训练目标，但各有几何偏好。例如，SSE 衡量中心量化误差，**轮廓系数**（silhouette coefficient）则比较样本到同簇其他样本的平均距离与到最近其他簇的平均距离，用来判断当前归属相对邻近簇是否更紧凑⁷⁰。这类指标不能作为目标不同的方法之间无条件的优劣排序。

⁶⁶ J. C. Gower, *A General Coefficient of Similarity and Some of Its Properties* In *Biometrics*, 1971, vol. 27, no. 4, pp. 857–871

⁶⁷ T. Ullmann, C. Hennig, A.-L. Boulesteix, *Validation of Cluster Analysis Results on Validation Data: A Systematic Framework* In *WIREs Data Mining and Knowledge Discovery*, 2022, vol. 12, no. 3, e1444

⁶⁸ S. Ben-David, U. von Luxburg, D. Pál, *A Sober Look at Clustering Stability* In *Learning Theory*, 2006, pp. 5–19

⁶⁹ R. Tibshirani, G. Walther, T. Hastie, *Estimating the Number of Clusters in a Data Set via the Gap Statistic* In *Journal of the Royal Statistical Society: Series B (Statistical Methodology)*, 2001, vol. 63, no. 2, pp. 411–423

⁷⁰ P. J. Rousseeuw, *Silhouettes: A Graphical Aid to the Interpretation and Validation of Cluster Analysis* In *Journal of Computational and Applied Mathematics*, 1987, vol. 20, pp. 53–65

比较同一批对象的两个划分时，**调整兰德指数**（adjusted Rand index, ARI）根据样本对的共簇或异簇关系衡量一致性，并在固定各簇大小的随机划分模型下校正期望一致⁷¹。它不依赖簇编号，可用于重复运行的稳定性比较，也可用于聚类与独立参考标签的比较；后一种用法检验指定语义，参考标签未必覆盖全部合理分组。

⁷¹ L. Hubert, P. Arabie, *Comparing Partitions* In Journal of Classification, 1985, vol. 2, no. 1, pp. 193–218

证据	最小执行协议	可以回答	不能单独推出
训练目标	在发现数据上记录 SSE、似然、图目标或约束违反，并只与相同目标和约束下的候选比较	求解是否满足方法声明的经验准则	语义正确、跨目标优越或样本外有效
稳定性	对象集固定而只改变测量、初始化或关键参数时，比较共簇关系或标签置换不变的分区分指标；样本重采样改变对象集时，只比较共同对象，或冻结新样本分配规则后再比较	哪些群组依赖少量样本、随机性或参数	正确簇数或业务语义；稳定性本身也可能来自唯一目标或数据对称性
外部标签	标签不参与无监督拟合与选择；在验证数据上按预先规定的总体或子群计算 ARI 等指标	与指定外部语义的一致程度	标签之外的其他合理结构，或无标签任务中的唯一真解
零模型	先说明要保留的边际、范围或相关结构；在每份模拟数据上重跑相同的预处理、拟合、候选搜索和选择规则；未重跑完整管线时只作为探索性基线	观察到的分离是否超出该无簇基线；Gap Statistic 是一个实例	拒绝所有其他零模型，或证明所得簇具有用途
留出证据	用发现数据拟合表示和模型，按冻结的新样本分配规则评价留出量化误差或预测对数密度	指定模型在同一数据制度下的样本外拟合	不同簇概念之间的统一优劣；无样本外规则的方法须先定义映射
下游效用	冻结簇提取流程，在嵌套验证中与无聚类或更简单基线比较检索、描述或决策损失	群组是否改善预先声明的实际用途	群组在其他用途或总体上仍然有效

表 4.3 聚类结果的评价协议。发现阶段可以生成和筛选候选；最终验证数据只在表示、算法、超参数和比较规则冻结后使用。每类证据回答不同问题，指标的几何偏好和数据依赖必须随结果报告。

证据冲突时，应回到预先声明的簇概念和用途收窄结论，而不是让某个分数覆盖其他结果。例如，更低 SSE 而更差下游效用，只能说明量化目标与用途不一致；高稳定性而不优于零模型，可能表示算法反复返回同一种任意结构；外部标签一致而留出密度较差，则提示标签语义与生成模型并不对应。训练目标、稳定性、外部标签、零模型、留出证据和下游效用不能互相替代。验证指标本身也会偏好特定簇形状和粒度，独立综述中的跨指标比较同样强调应按问题选择证据⁷²。

评价准则还取决于输出对象。Kleinberg 证明，对固定对象集、以成对距离为输入并输出单一划分的聚类函数，尺度不变性、丰富性与一致性不能同时满足。这个结论说明某些自然要求之间存在冲突，不能直接推广到软归属、重叠簇或层次输出⁷³。流式、多视图和神经聚类还会改变数据制度或表示学习方式，其评价也需随之调整。

⁷² J. Handl, J. Knowles, D. B. Kell, *Computational Cluster Validation in Post-Genomic Data Analysis* In Bioinformatics, 2005, vol. 21, no. 15, pp. 3201–3212

⁷³ J. Kleinberg, *An Impossibility Theorem for Clustering* In Advances in Neural Information Processing Systems, 2002, pp. 463–470

理论结论应跟着其证明对象使用。Lloyd 的有限停止依赖下降与平局规则；Ward 的最优性只针对当前一次合并；DBSCAN 的顺序不变性只保证核心点划分。Mean Shift 和 EM 的单调性不能单独推出参数收敛，谱松弛最优不等于离散图割最优，CLIQUE 的安全剪枝也不消除指数最坏情况。区分这些边界，才能把算法解释转化为可靠的实现。

从问题驱动的角度看，聚类方法的演进可按七种压力理解，而不是按年份排成替代顺序。规模扩大促成小批量更新、抽样和数据摘要，却加入近似误差与顺序敏感性；非凸结构使密度连通、核和谱方法超越单中心表示，同时引入邻域尺度、核或构图选择；关系输入让 K-medoids 与图目标直接使用对象间联系，代价是平方存储或图计算；高维表示推动子空间和投影聚类，却增加组合搜索与估计误差；概率语义带来软后验、预测密度与模型比较，也带来分布失配、奇异性和局部推断；弱监督用关系、种子或少量类别标签消除部分歧义，但错误与冲突先验可能被放大；验证需求则把注意力从单次输出转向零模型、重复性、独立数据和用途证据。后来的路线通常改变其中一个条件，并不自动支配其他条件下的经典方法。

回到客户分群，只有先说明分组将服务于量化、探索、解释还是下游决策，才能依次选择变量与尺度、相异度或邻接、簇判据、输出粒度和先验。需要快速数值量化，可从 K-means 开始；需要真实代表或一般相异度，可用 K-medoids；需要多粒度解释，采用层次树；需要低密度分隔与噪声识别，考察 DBSCAN、OPTICS 或 HDBSCAN；原始输入就是关系时，先说明边权含义再选择图目标。相关变量因簇而异时考虑子空间，后验和预测密度重要时考虑混合模型，已有可靠领域知识时再决定如何加入约束或种子。

候选确定后，再按表4.3检验其用途：量化看留出误差，探索看稳定性与零模型，语义解释看独立外部关联，下游决策看相对于无聚类基线的效用。结论应限于这些证据实际支持的客户群体与使用条件。

4.10 本章小结

没有类别答案时，簇由结构假设界定：原型描述紧凑群组，邻域与图描述连接，网格与子空间寻找局部相关区域，层次保留嵌套分组，概率模型解释软归属，集成汇总成员分组。监督关系还可以加入这些方法，约束它们原本无法区分的选择。

分组是否有用，需要另行验证。训练目标、稳定性、外部标签、零模型、留出表现和下游效用回答不同问题，不能由一次收敛或一项内部指标代替。即使算法不直接指定 K ，密度阈值、带宽、截线或先验也仍在控制粒度。

第5章进一步改变表示，因而也可能改变距离、密度和邻接关系。低维图形可以帮助探索群组，其分离仍需在原始或经过验证的表示中检验。

降维

基因测量或文档向量可能有成千上万个坐标，分析却只需要其中部分变化。**降维**（dimensionality reduction）把观测 $\mathbf{x} \in \mathbb{R}^d$ 转为表示 $\mathbf{z} \in \mathbb{R}^k$ ，通常取 $k \ll d$ 。保留方差、距离、邻域或生成因素是不同目标；低维表示是否有用，还要看它怎样影响后续预测、分组或解释。

20 世纪初的 PCA 从线性变化中提取主方向，1950 年代的 MDS 从对象差异恢复坐标。1990 年代的核 PCA 扩展了非线性表示，2000 年前后的 Isomap 与 LLE 转向局部几何；2008 年的 t-SNE 和 2018 年的 UMAP 进一步推动了高维数据的可视化¹。

现在，PCA 仍是压缩、去噪和建模前处理的常见基线，t-SNE 与 UMAP 则常用于探索局部邻域结构。图上的分离可以提出假设，仍需回到原始表示和任务证据检验²。本章依次讨论线性关系及核扩展、距离、邻域与概率方法：分别保留全局组合、点间差异、局部关系或生成因素。

以下用 n 表示样本数， $\mathbf{X} \in \mathbb{R}^{n \times d}$ 与 $\mathbf{Z} \in \mathbb{R}^{n \times k}$ 按行存放观测和低维表示，邻居数记为 q ，内在维数记为 m 。“表示”统称变换结果，“嵌入”强调几何或邻域坐标，“潜变量”则指参与生成但未被观测的量。共享建模机制见第1章。

5.1 基于线性关系的降维

如果多个传感器的读数主要随同一个物理量一起变化，那么数据可能集中在一条直线附近。推广到多个变化因素，就得到低维线性子空间。线性投影用 $\mathbf{z} = \mathbf{W}^\top(\mathbf{x} - \boldsymbol{\mu})$ 描述这一结构，其中 $\mathbf{W} \in \mathbb{R}^{d \times k}$ 为列正交的基矩阵， $\boldsymbol{\mu}$ 为中心；对应的正交投影算子是 $\mathbf{W}\mathbf{W}^\top$ 。学习后，新样本只需一次矩阵乘法；投影的每一维也能追溯到原特征的线性组合。

本节还讨论非负矩阵分解和稀疏编码。它们的共同点是用基向量的线性组合重构观测，但编码通常要求解约束优化，未必是输入的线性函数。统计独立性也不只依赖协方差。因此，“线性”在本节中既包括线性编码，也包括线性重构；不能据此把所有方法归结为二阶统计量或一次特

¹ B. Schölkopf, A. Smola, K.-R. Müller, *Nonlinear Component Analysis as a Kernel Eigenvalue Problem* In *Neural Computation*, 1998, vol. 10, no. 5, pp. 1299–1319; J. B. Tenenbaum, V. de Silva, J. C. Langford, *A Global Geometric Framework for Nonlinear Dimensionality Reduction* In *Science*, 2000, vol. 290, no. 5500, pp. 2319–2323

² scikit-learn developers, *Decomposing Signals in Components*, scikit-learn User Guide, URL: <https://scikit-learn.org/stable/modules/decomposition.html> (visited on 10/04/2026); L. McInnes, J. Healy, N. Saul, L. Großberger, *UMAP: Uniform Manifold Approximation and Projection* In *Journal of Open Source Software*, 2018, vol. 3, no. 29, pp. 861

征分解。核 PCA 随后把方差目标放到简介定义的特征空间中；这里的线性关系可以针对编码、生成或映射后的特征，三者不能混为同一种原空间线性投影。

5.1.1 主成分分析 (PCA)

选择一个投影方向时，可以问投影以后还剩多少变化，也可以问由投影恢复原样本会损失多少信息。**主成分分析** (principal component analysis, PCA) 在平方误差和正交投影的设定下给出同一个答案：选择方差最大的方向，就得到平均重构误差最小的子空间。Pearson 在 1901 年研究点集的最佳拟合直线与平面，Hotelling 在 1933 年从多元统计角度讨论主成分；这两条表述分别突出了几何拟合与变量变化的分解³。

5.1.1.1 模型结构

本小节先规定标准 PCA 优化什么对象，以及投影得分怎样重构观测；具体求解留到下一小节。先减去样本均值，以下暂以 $\mathbf{X}$ 表示中心化后的数据矩阵，定义样本协方差 $\mathbf{S} = \mathbf{X}^T \mathbf{X} / n$ 。本章采用分母 n ，它与最大似然中的协方差约定一致；改用 $n - 1$ 只会整体缩放特征值，不改变主成分方向。

在单位方向 $\mathbf{w}$ 上的投影方差为 $\mathbf{w}^T \mathbf{S} \mathbf{w}$ 。选择 k 个正交单位方向组成 $\mathbf{W}$ ，得到

$$\max_{\mathbf{W}^T \mathbf{W} = \mathbf{I}_k} \text{tr}(\mathbf{W}^T \mathbf{S} \mathbf{W}), \quad \mathbf{Z} = \mathbf{X} \mathbf{W}. \quad (5.1)$$

式中的 $\mathbf{W}$ 是候选 k 维子空间的一组正交基；目标只取决于它张成的子空间，并未要求每一列都是协方差矩阵的特征向量。投影得分 $\mathbf{z} = \mathbf{W}^T \mathbf{x}$ 与基向量本身是不同对象。

由得分重构中心化样本为 $\hat{\mathbf{x}} = \mathbf{W} \mathbf{W}^T \mathbf{x}$ 。残差与子空间正交，勾股关系给出

$$\|\mathbf{x} - \hat{\mathbf{x}}\|_2^2 = \|\mathbf{x}\|_2^2 - \|\mathbf{W}^T \mathbf{x}\|_2^2. \quad (5.2)$$

对样本取平均，第一项与 $\mathbf{W}$ 无关，所以最大化投影方差等价于最小化平均平方重构误差。图5.1展示了这两个量的几何关系。对未经中心化的新观测，编码时减去训练均值，重构时再加回均值。

5.1.1.2 参数学习

模型目标确定后，本小节说明怎样计算一个最优表示，并区分解析解与数值近似。对单位方向的约束问题引入乘子 λ ，驻点满足 $\mathbf{S} \mathbf{w} = \lambda \mathbf{w}$ ，此时方差正好为 λ 。将特征值排序为 $\lambda_1 \geq \dots \geq \lambda_d \geq 0$ ，前 k 个特征向量组成 $\mathbf{V}_k$ ； $\mathbf{V}_k$ 的列称为**主成分方向** (principal component directions)。取 $\mathbf{W} = \mathbf{V}_k$ 便得到一个解析解，此时得分 $\mathbf{X} \mathbf{V}_k$ 的经验协方差为 $\text{diag}(\lambda_1, \dots, \lambda_k)$ ，所以各主成分得分不相关；这还不意味着统计独立。

³ K. Pearson, *On Lines and Planes of Closest Fit to Systems of Points in Space* In The London, Edinburgh, and Dublin Philosophical Magazine and Journal of Science, 1901, vol. 2, no. 11, pp. 559–572; H. Hotelling, *Analysis of a complex of statistical variables into principal components*. In Journal of Educational Psychology, 1933, vol. 24, no. 6, pp. 417–441




图 5.1 二维到一维的正交投影示意。蓝色实线方向 w_1 是保留的第一主轴，红色虚线方向 w_2 是被舍弃的正交主轴。点 x 投到 $\hat{x}$ ，重构残差沿 w_2 方向。图中散点为示意位置，未表示真实实验。

这里三个不能混同的对象。一般的最优 W 是所选主子空间的一组正交基矩阵， $\text{span}(W)$ 是主子空间， $P = WW^T$ 是到该子空间的投影算子。若 $\lambda_k > \lambda_{k+1}$ ，主子空间与投影算子唯一，但最优 W 仍不唯一：任意 k 阶正交矩阵 Q 都使 WQ 给出同一投影，而所有最优基均可写成 $V_k Q$ 。若从 $W = V_k$ 出发，且 Q 混合不同特征值对应的方向，则 WQ 的列一般不再是 S 的特征向量，得分协方差 $Q^T \text{diag}(\lambda_1, \dots, \lambda_k) Q$ 一般也不再是对角矩阵。因此，主成分方向和互不相关的主成分得分特指排序特征向量基 V_k 及其得分，而不是主子空间的每一组最优正交基。若还要求各列是按特征值排序的特征向量，则单特征值对应的方向只差符号，所选范围内的重特征值允许在整个重特征子空间中旋转。若 $\lambda_k = \lambda_{k+1}$ 使重特征值跨过截断位置，最优主子空间和投影算子一般也不唯一。

数值计算通常直接对数据作**奇异值分解** (singular value decomposition, SVD)，即 $X = U\Sigma V^T$ 。右奇异向量给出方向， $\lambda_j = \sigma_j^2/n$ ，得分为 $U_k \Sigma_k$ 。直接 SVD 避免显式形成 $X^T X$ 所带来的条件数平方问题。完整稠密分解约需 $O(nd \min(n, d))$ 次运算；当只要少数方向时，截断算法可以降低开销，不能把形成 $d \times d$ 协方差矩阵的代价当成所有 PCA 实现的下界。

若 $d \gg n$ ，也可以分解 $n \times n$ 的 Gram 矩阵 XX^T 。若 $XX^T u_j = \sigma_j^2 u_j$ 且 $\sigma_j > 0$ ，则 $v_j = X^T u_j / \sigma_j$ 。这是同一 SVD 的两侧表示；第 5.1.7 节将把这种样本空间计算推广到核函数。

维数选择常用**累计解释方差** (cumulative explained variance)，即

$$\eta_k = \frac{\sum_{j=1}^k \lambda_j}{\sum_{j=1}^d \lambda_j}. \quad (5.3)$$

分母非零时, 可按预先约定的比例选 k , 或查看特征值随序号下降的碎石图。85%、95% 等比例只是经验阈值: 低方差方向可能包含第3.1.1.4节所关心的类别判别信息, 高方差方向也可能来自量纲或背景干扰。特征单位差异很大时, 是否标准化要由任务决定; 若用于预测, 应在训练集内部用验证性能选择维数。

对大型矩阵, 随机化 SVD 先构造近似列空间, 再在较小矩阵上分解; 增量 PCA 则分批更新子空间。这些算法以近似误差或更新规则换取内存、时间收益, 均需把求解误差与 PCA 目标本身区分⁴。

5.1.1.3 理论分析

收敛性分析 前两小节给出了问题设定与求解方式; 这里先分析固定数据上的经验最优性, 再在“泛化分析”中转向有限样本估计总体结构的问题。PCA 的解析最优性是关于给定数据的结论。这个结论也可由 Eckart-Young 低秩逼近定理得到⁵。

主线阅读只需记住: 在正交投影和平方重构误差下, 前 k 维主子空间达到经验全局最优, 最小误差等于被舍弃特征值之和。下面的进阶证明把这一结论化为特征值加权和, 并用截断处的谱隙判断子空间何时唯一; 它不负责说明有限样本估计是否接近总体子空间。

定理 5.1 PCA 的最优线性重构性质 设 $\mathbf{X}$ 已中心化, $1 \leq k < d$, λ_j 为 $\mathbf{S} = \mathbf{X}^\top \mathbf{X} / n$ 按降序排列的特征值。则

$$\min_{\mathbf{W}^\top \mathbf{W} = \mathbf{I}_k} \frac{1}{n} \|\mathbf{X} - \mathbf{X} \mathbf{W} \mathbf{W}^\top\|_F^2 = \sum_{j=k+1}^d \lambda_j.$$

前 k 个特征向量张成的子空间达到最小值。若 $\lambda_k > \lambda_{k+1}$, 最优投影算子 $\mathbf{W} \mathbf{W}^\top$ 唯一, 但子空间内的正交基不唯一。

证明. 由式(5.2), 经验误差等于 $\text{tr}(\mathbf{S}) - \text{tr}(\mathbf{W}^\top \mathbf{S} \mathbf{W})$ 。写 $\mathbf{S} = \mathbf{V} \mathbf{\Lambda} \mathbf{V}^\top$, 令 $\mathbf{A} = \mathbf{V}^\top \mathbf{W}$, 则 $\mathbf{A}^\top \mathbf{A} = \mathbf{I}_k$ 。记 $a_j = \|\mathbf{A}_{j,:}\|_2^2$, 有 $0 \leq a_j \leq 1$ 及 $\sum_j a_j = k$ 。上界来自 $\mathbf{A} \mathbf{A}^\top$ 是正交投影, 每个对角元不超过 1。

令 $u = \sum_{j>k} a_j = \sum_{j \leq k} (1 - a_j)$ 。按特征值次序,

$$\begin{aligned} \sum_{j=1}^k \lambda_j - \sum_{j=1}^d \lambda_j a_j &= \sum_{j \leq k} \lambda_j (1 - a_j) - \sum_{j>k} \lambda_j a_j \\ &\geq (\lambda_k - \lambda_{k+1}) u \geq 0. \end{aligned}$$

因此保留方差最多为 $\sum_{j \leq k} \lambda_j$, 取 $\mathbf{W} = \mathbf{V}_k$ 达到该值。若边界处有严格谱隙, 等号要求 $u = 0$, 因而投影到唯一的前 k 维子空间。若 $\lambda_k = \lambda_{k+1}$, 可

⁴ N. Halko, P. G. Martinsson, J. A. Tropp, *Finding Structure with Randomness: Probabilistic Algorithms for Constructing Approximate Matrix Decompositions* In SIAM Review, 2011, vol. 53, no. 2, pp. 217–288

⁵ C. Eckart, G. Young, *The Approximation of One Matrix by Another of Lower Rank* In Psychometrika, 1936, vol. 1, no. 3, pp. 211–218

以在跨越截断位置的重特征值空间中选择不同子空间，仍有相同误差。■

这个定理刻画了数值算法要逼近的全局最优解。使用迭代谱算法时，还应检查特征方程残差与方向的正交误差；求解精度不足造成的误差，不能与有限样本的估计误差混合。固定数据下把迭代做得更充分，可以改善前者，却不会自动改善后者。

泛化分析 定理中的平均值是训练样本平均，不能直接改写为未知分布下的期望。若总体中心为 $\mathbf{0}$ 、协方差为 $\Sigma_\star$ ，则总体重构风险为 $R(\mathbf{P}) = \text{tr}((\mathbf{I} - \mathbf{P})\Sigma_\star)$ ，其中 $\mathbf{P}$ 为秩 k 正交投影。设 $\hat{\mathbf{P}}$ 最小化样本风险， $\mathbf{P}_\star$ 最小化总体风险，加入并减去样本协方差项可得

$$\begin{aligned} R(\hat{\mathbf{P}}) - R(\mathbf{P}_\star) &\leq \text{tr}((\mathbf{P}_\star - \hat{\mathbf{P}})(\Sigma_\star - \mathbf{S})) \\ &\leq 2k\|\mathbf{S} - \Sigma_\star\|_2. \end{aligned} \quad (5.4)$$

第一步使用 $\hat{\mathbf{P}}$ 的经验最优性。第二步使用 $\mathbf{P}_\star - \hat{\mathbf{P}}$ 的核范数至多为 $2k$ ，其中核范数是矩阵奇异值之和。若编码还使用样本均值，总体重构风险另外包含均值估计误差。在固定 d 、独立同分布且二阶矩有限时，样本均值与协方差依大数定律收敛，风险差因此趋于零。方向估计还取决于谱隙；特征值十分接近时，小协方差扰动也可能使方向明显旋转，而重构误差变化很小。

当 d 与 n 同步增长时，固定维数结论不能直接沿用。Nadler 对尖峰协方差模型的有限样本与渐近分析说明，样本特征值和方向可能偏离总体值，弱信号甚至不能被一致识别⁶。Marchenko–Pastur 型谱极限给出了这种区别的一个基准：在独立同分布噪声且 d/n 趋于正常数的典型设定中，即使总体协方差是单位矩阵，样本特征值也不会全部收缩到 1，而会形成非退化的极限谱分布⁷。这一结论有明确的矩阵与比例极限条件，并不是对任意总体谱都适用的统一纠偏公式。

稀疏 PCA 利用载荷结构减少有效自由度；奇异值阈值或收缩则调整谱幅度，适合低秩矩阵去噪等设定。两条路线的假设不同，例如 Donoho 与 Gavish 研究的最优硬阈值依赖具体噪声和损失条件，不能当作所有高维 PCA 的默认修正⁸。

5.1.1.4 支持稀疏载荷 (Sparse PCA)

前述小节分别给出标准 PCA 的设定、求解和论证；下面两小节改变载荷约束与污染模型，属于模型扩展。标准主成分可能包含几乎所有原始特征，难以说明哪些变量共同驱动某个方向。**稀疏 PCA** (sparse PCA) 限制主成分载荷中的非零项，使一个成分主要由少数变量表达。Zou、Hastie 与 Tibshirani 在 2006 年将 PCA 改写为回归式矩阵分解，把主成分提取与

⁶ B. Nadler, *Finite sample approximation results for principal component analysis: A matrix perturbation approach* In The Annals of Statistics, 2008, vol. 36, no. 6, pp. 2791–2817

⁷ V. A. Marchenko, L. A. Pastur, *Distribution of Eigenvalues for Some Sets of Random Matrices* In Mathematics of the USSR-Sbornik, 1967, vol. 1, no. 4, pp. 457–483

⁸ M. Gavish, D. L. Donoho, *The Optimal Hard Threshold for Singular Values Is $4/\sqrt{3}$* In IEEE Transactions on Information Theory, 2014, vol. 60, no. 8, pp. 5040–5053

回归中的变量选择联系起来，并讨论了基因表达等高维数据的计算问题⁹。这一路线直接把稀疏要求纳入优化目标，而不是先求普通主成分再删去小载荷：

$$\min_{\mathbf{A}, \mathbf{B}} \|\mathbf{X} - \mathbf{XBA}^\top\|_F^2 + \lambda_1 \sum_{j=1}^k \|\mathbf{b}_j\|_1 + \lambda_2 \|\mathbf{B}\|_F^2, \quad (5.5)$$

$$\text{约束 } \mathbf{A}^\top \mathbf{A} = \mathbf{I}_k.$$

这里 $\mathbf{A}, \mathbf{B} \in \mathbb{R}^{d \times k}$ ， $\mathbf{b}_j$ 为 $\mathbf{B}$ 第 j 列， $\lambda_1, \lambda_2 \geq 0$ 。 $\mathbf{B}$ 控制编码载荷， $\mathbf{A}$ 控制重构方向。 ℓ_1 项促使载荷稀疏，平方惩罚缓解相关变量下的数值不稳定。

固定 $\mathbf{A}$ 时，把 $\mathbf{X}$ 分解到 $\mathbf{A}$ 的列空间及其正交补，便有

$$\|\mathbf{X} - \mathbf{XBA}^\top\|_F^2 = \|\mathbf{XA} - \mathbf{XB}\|_F^2 + \|\mathbf{X}(\mathbf{I} - \mathbf{AA}^\top)\|_F^2.$$

后一项与 $\mathbf{B}$ 无关，因此各列成为弹性网回归。固定 $\mathbf{B}$ 时，最大化 $\text{tr}(\mathbf{A}^\top \mathbf{X}^\top \mathbf{XB})$ 是正交 Procrustes 问题，可由 SVD 求解。交替更新通常得到局部解，需要检查初始化和惩罚强度的敏感性。

稀疏性提高了变量筛选层面的可读性，却改变了标准 PCA 的正交结构： $\mathbf{B}$ 各列通常不正交，得分也未必不相关，不能直接把各稀疏成分方差相加当作无重叠的解释方差。基因表达、文本等高维场景中，应同时报告稀疏程度、重构效果与跨样本稳定性。

5.1.1.5 支持异常值与低秩加稀疏分解 (Robust PCA)

稀疏 PCA 约束载荷中使用哪些变量，本小节则改变观测误差的结构。平方误差会放大幅度很大的污染值。例如固定摄像机的视频中，背景随帧变化较少，运动前景却会改变少数像素。把各帧排成矩阵，便可尝试将观测 $\mathbf{M} \in \mathbb{R}^{n \times d}$ 拆为低秩背景 $\mathbf{L}$ 与稀疏扰动 $\mathbf{E}$ 。**鲁棒 PCA** (robust PCA, RPCA) 在这里指这种低秩加稀疏分解；它只是稳健子空间估计的一种形式。

直接最小化 $\text{rank}(\mathbf{L}) + \lambda \|\mathbf{E}\|_0$ 具有组合困难。**主成分追踪** (principal component pursuit, PCP) 用凸惩罚替代这两个量：

$$\min_{\mathbf{L}, \mathbf{E}} \|\mathbf{L}\|_* + \lambda \|\mathbf{E}\|_1, \quad \mathbf{M} = \mathbf{L} + \mathbf{E}. \quad (5.6)$$

$\|\mathbf{L}\|_* = \sum_j \sigma_j(\mathbf{L})$ 是核范数， $\|\mathbf{E}\|_1$ 在这里指所有元素绝对值之和。前者鼓励少数非零奇异值，后者鼓励少数非零元素。

可恢复性要求两部分能够区分：若一个矩阵本身既低秩又稀疏，就可能在 $\mathbf{L}$ 与 $\mathbf{E}$ 之间任意转移。Candès 等的精确恢复定理要求低秩部分满足不相干性，即奇异向量不集中在少数坐标上，并对秩、稀疏污染比例及随机支持作出限制。在这些条件下， $\lambda = 1/\sqrt{\max(n, d)}$ 可作为无需知道污染幅度的理论选择；任意位置的对抗性污染不自动满足该保证¹⁰。

⁹ H. Zou, T. Hastie, R. Tibshirani, *Sparse Principal Component Analysis* In Journal of Computational and Graphical Statistics, 2006, vol. 15, no. 2, pp. 265–286

¹⁰ E. J. Candès, X. Li, Y. Ma, J. Wright, *Robust principal component analysis?* In Journal of the ACM, 2011, vol. 58, no. 3, pp. 1–37

求解可采用**交替方向乘法**(alternating direction method of multipliers, ADMM), 将两个惩罚项分开处理, 再协调重构约束。给定惩罚参数 $\rho > 0$, 引入与 $\mathbf{M}$ 同形的辅助矩阵 $\mathbf{U}$, 它是除以 ρ 后的拉格朗日乘子, 称为缩放对偶变量。固定 $\mathbf{U}$, 略去与 $\mathbf{L}, \mathbf{E}$ 无关的常数, 增广目标为

$$\|\mathbf{L}\|_* + \lambda \|\mathbf{E}\|_1 + \frac{\rho}{2} \|\mathbf{M} - \mathbf{L} - \mathbf{E} + \mathbf{U}\|_F^2.$$

先固定 $\mathbf{E}$ 求 $\mathbf{L}$, 再固定新的 $\mathbf{L}$ 求 $\mathbf{E}$, 便得到两种阈值更新; 随后让 $\mathbf{U}$ 累加本轮尚未消除的重构误差, 使后续子问题继续校正约束偏差。通常从 $\mathbf{U}^{(0)} = \mathbf{0}$ 开始, 一次更新分别为

$$\begin{aligned} \mathbf{L}^{(t+1)} &= \text{SVT}_{1/\rho}(\mathbf{M} - \mathbf{E}^{(t)} + \mathbf{U}^{(t)}), \\ \mathbf{E}^{(t+1)} &= \mathcal{S}_{\lambda/\rho}(\mathbf{M} - \mathbf{L}^{(t+1)} + \mathbf{U}^{(t)}), \\ \mathbf{U}^{(t+1)} &= \mathbf{U}^{(t)} + \mathbf{M} - \mathbf{L}^{(t+1)} - \mathbf{E}^{(t+1)}. \end{aligned} \quad (5.7)$$

$\mathcal{S}_a(u) = \text{sign}(u)(|u| - a)_+$ 逐元素软阈值化, SVT_a 则对奇异值作同样操作。 $\mathbf{E}$ 表示模型中的稀疏扰动, $\mathbf{U}$ 则记录迭代累积的约束误差, 两者承担不同职责。固定 ρ 时, 停止所需的两类残差大小为

$$\begin{aligned} r_{\text{pri}}^{(t+1)} &= \|\mathbf{M} - \mathbf{L}^{(t+1)} - \mathbf{E}^{(t+1)}\|_F, \\ r_{\text{dual}}^{(t+1)} &= \rho \|\mathbf{E}^{(t+1)} - \mathbf{E}^{(t)}\|_F. \end{aligned}$$

原始残差衡量重构等式是否满足; 对偶残差衡量第二个子问题的变化是否仍使刚求出的第一个子问题偏离平衡。两者都应低于结合数据尺度设置的容差, 不能用固定的“几十次迭代”保证收敛。

若观测还有小幅稠密噪声, 可将等式约束改成 $\|\mathbf{M} - \mathbf{L} - \mathbf{E}\|_F \leq \delta$, 得到稳定 PCP 形式。在线、带侧信息的变体分别面向流式观测和已知子空间特征。视频背景、图像遮挡与异常检测是否适用, 取决于污染是否符合所选稀疏模型; 整行异常常需组稀疏惩罚, 不能简单套用逐元素稀疏假设。

5.1.1.6 小结

PCA 给出正交线性压缩的经验平方误差最优解, 同时提供可复用的编码与重构公式。维数、尺度和异常值会改变得到的子空间; 总体可靠性还受样本量与谱隙影响。稀疏 PCA 改变载荷结构, RPCA 改变污染模型, 第 5.4.1 节的概率 PCA 则显式描述噪声与潜变量。这些扩展分别回答不同问题, 不能用一个“改进 PCA”的名称替代条件比较。

5.1.2 典型相关分析 (CCA)

一张图像与它的文字描述具有不同坐标, 却可能反映共同内容。单独在两个视图中保留最大方差方向, 并不能保证保留的是共有变化。**典型相关分**

析 (canonical correlation analysis, CCA) 为成对观测各找一组投影, 使对应得分的相关系数尽可能大。Hotelling 的经典工作建立了这一双视图分析框架¹¹。

¹¹ H. Hotelling, *Relations between Two Sets of Variates In Biometrika*, 1936, vol. 28, no. 3-4, pp. 321-377

5.1.2.1 模型结构

设中心化成对观测为 $\mathbf{x} \in \mathbb{R}^{d_x}$ 、 $\mathbf{y} \in \mathbb{R}^{d_y}$, 协方差为 Σ_{xx} 、 Σ_{yy} , 交叉协方差为 $\Sigma_{xy} = \mathbb{E}[\mathbf{x}\mathbf{y}^\top]$ 。实际计算时用同一批配对样本估计这些矩阵。第一对典型方向求解

$$\max_{\mathbf{w}_x, \mathbf{w}_y} \frac{\mathbf{w}_x^\top \Sigma_{xy} \mathbf{w}_y}{\sqrt{\mathbf{w}_x^\top \Sigma_{xx} \mathbf{w}_x} \sqrt{\mathbf{w}_y^\top \Sigma_{yy} \mathbf{w}_y}}. \quad (5.8)$$

分母要求两个投影具有非零方差。由于尺度不影响相关性, 可固定两侧投影方差为 1, 只最大化分子。

图5.2把这一目标与 PCA 放在同一个例子中比较。两侧各自方差最大的坐标分别为 u 和 v , 它们相互独立; 较小方差的坐标却都是 t 。因此, 保留最多变化与保留共有变化会选择不同方向。这里保留各坐标的原方差; 若先逐坐标标准化, PCA 的方向选择也会改变。




图 5.2 CCA 提取共有变化的构造例子。设 t, u, v 相互独立且均值为零, 方差依次为 1, 4, 4; 两视图为 $\mathbf{x} = (t, u)^\top$ 和 $\mathbf{y} = (v, t)^\top$ 。实线连接共享因素, 虚线连接各视图独有因素。各保留一维时, PCA 选择 u, v , CCA 选择 t, t , 对应相关系数分别为 0 和 1。箭头表示坐标构造关系, 图中结论针对给定总体, 不是样本拟合结果。

提取多对方向时, 同一视图内要求 $\mathbf{W}_x^\top \Sigma_{xx} \mathbf{W}_x = \mathbf{I}_k$ 和 $\mathbf{W}_y^\top \Sigma_{yy} \mathbf{W}_y = \mathbf{I}_k$ 。这是协方差度量下的正交, 通常不是原坐标中的欧氏正交。对应跨视图得分协方差可对角化为 $\text{diag}(\rho_1, \dots, \rho_k)$ 。可识别的对数受维数、样本秩和交叉协方差秩共同限制。

5.1.2.2 参数学习

假设两侧协方差正定，先用白化把各自协方差变为单位阵。令

$$\mathbf{K} = \Sigma_{xx}^{-1/2} \Sigma_{xy} \Sigma_{yy}^{-1/2}, \quad \mathbf{K} = \mathbf{U} \mathbf{D} \mathbf{V}^\top.$$

若设 $\mathbf{a} = \Sigma_{xx}^{1/2} \mathbf{w}_x$ 、 $\mathbf{b} = \Sigma_{yy}^{1/2} \mathbf{w}_y$ ，目标就成为单位向量约束下的 $\max \mathbf{a}^\top \mathbf{K} \mathbf{b}$ 。最大值为 $\mathbf{K}$ 最大奇异值，取相应左右奇异向量达到。因此

$$\mathbf{W}_x = \Sigma_{xx}^{-1/2} \mathbf{U}_k, \quad \mathbf{W}_y = \Sigma_{yy}^{-1/2} \mathbf{V}_k, \quad (5.9)$$

而 $\mathbf{D}$ 的前 k 个对角元就是典型相关系数。数值上可用 Cholesky 分解与三角求解实现白化，无须显式求逆。

对约束目标求导也可得到 $\Sigma_{xy} \mathbf{w}_y = \rho \Sigma_{xx} \mathbf{w}_x$ 及另一侧的对称关系。消去 $\mathbf{w}_y$ ，便有

$$\Sigma_{xy} \Sigma_{yy}^{-1} \Sigma_{yx} \mathbf{w}_x = \rho^2 \Sigma_{xx} \mathbf{w}_x.$$

这解释了 CCA 与广义特征值问题的联系。若样本协方差奇异，可在非零方差子空间求解，或分别加 $\lambda_x \mathbf{I}$ 、 $\lambda_y \mathbf{I}$ 进行正则化。后一种做法改变了归一化度量，应通过留出配对样本检查相关性，而不能只看训练相关系数。

核 CCA 以核特征替代原特征，深度 CCA 进一步学习非线性变换¹²。Andrew 等在 2013 年提出深度 CCA 时，关注的不只是非线性表示，还包括固定核对表示的限制，以及新样本计算对训练样本的依赖。他们改用两条联合学习的参数化映射，保留相关性目标，使新样本可以通过前向计算获得表示。这些扩展改变了表示形式与计算方式，也需要额外的复杂度控制。

¹² G. Andrew, R. Arora, J. Bilmes, K. Livescu, *Deep Canonical Correlation Analysis* In Proceedings of the 30th International Conference on Machine Learning, 2013, pp. 1247–1255

5.1.2.3 小结

CCA 寻找两个视图的共同线性变化，适合配对传感器、多模态匹配和跨域分析。它最大化相关而非因果效应，也不保证保留每个视图中所有重要信息。高维小样本时训练相关性容易被高估，正则化与样本外检验尤其必要。现代双塔表示与对比学习也处理多视图对齐，但负采样、损失和训练机制并不能直接由 CCA 推得。

5.1.3 独立成分分析 (ICA)

不相关仍可能高度依赖。例如 $X \sim \mathcal{N}(0, 1)$ 时， X 与 X^2 的协方差为零，后者却由前者完全确定。如果观测是多个源信号的混合，仅去除相关性还不足以分离源。**独立成分分析** (independent component analysis, ICA) 利用分量独立性和非高斯结构估计混合过程，典型任务包括分离说话人、脑电活动与眼动伪迹¹³。

¹³ P. Comon, *Independent component analysis, A new concept?* In Signal Processing, 1994, vol. 36, no. 3, pp. 287–314

ICA 也与信息论和早期神经网络研究相交。Bell 与 Sejnowski 在 1995 年从非线性网络的信息传递出发推导学习规则，利用超出协方差的统计信息减少输出之间的依赖¹⁴。原论文同时研究未知混合语音的分离和未知回声的消除，将信息最大化思路用于两类盲信号处理问题。这里“盲”指混合或传播过程未知，并非不对源信号作出假设。

¹⁴ A. J. Bell, T. J. Sejnowski, *An Information-Maximization Approach to Blind Separation and Blind Deconvolution* In *Neural Computation*, 1995, vol. 7, no. 6, pp. 1129–1159

5.1.3.1 模型结构

先考虑中心化、无噪声且源数等于通道数的模型

$$\mathbf{x} = \mathbf{A}\mathbf{s}, \quad \mathbf{z} = \mathbf{W}^\top \mathbf{x}, \quad \mathbf{W}^\top = \mathbf{A}^{-1}. \quad (5.10)$$

其中 $\mathbf{A} \in \mathbb{R}^{d \times d}$ 可逆， $\mathbf{s}$ 的分量相互独立。这里 $\mathbf{W}$ 按列存放解混方向，因此 $\mathbf{W} = \mathbf{A}^{-\top}$ ；若把解混矩阵定义为 $\mathbf{A}^{-1}$ ，编码就应写成左乘该矩阵，不能混用两种约定。

经典可识别性还要求源非退化，且至多一个源为高斯。多个标准高斯源的联合分布在正交旋转下不变，观测无法区分该高斯子空间内的不同方向。即使条件满足，源的排列和尺度仍无法仅由观测确定：交换源及对应混合列、同时反向缩放两者，都不改变 $\mathbf{x}$ 。

若解混后密度存在，可以用分量联合分布相对于边际分布乘积的 KL 散度衡量剩余依赖：

$$I(z_1, \dots, z_d) = \sum_{j=1}^d h(z_j) - h(\mathbf{z}),$$

其中 h 为微分熵，表达式要求相应量有定义。它为零当且仅当分量独立。另一种路线在单位方差约束下最大化非高斯性，例如负熵 $J(\mathbf{z}) = h(\mathbf{g}) - h(\mathbf{z})$ ， $\mathbf{g}$ 是同均值、同方差的高斯变量。独立变量相加常使分布更接近高斯，这为分离提供直觉；中心极限定理本身并不保证任意有限线性组合的所有非高斯性指标都严格单调。

若为源选择密度 p_j ，变量替换给出对数似然

$$\ell(\mathbf{W}) = n \log |\det \mathbf{W}| + \sum_{i=1}^n \sum_{j=1}^d \log p_j(\mathbf{w}_j^\top \mathbf{x}_i). \quad (5.11)$$

行列式项来自解混的 Jacobian。互信息、非高斯性与似然提供相关视角，但采用近似对比函数或错误的源密度时，其优化解不必完全相同。

5.1.3.2 参数学习

通常先做**白化** (whitening)，把协方差变为单位阵：若 $\mathbf{S} = \mathbf{V}\mathbf{\Lambda}\mathbf{V}^\top$ 且保留特征值为正，令 $\tilde{\mathbf{x}} = \mathbf{\Lambda}^{-1/2}\mathbf{V}^\top \mathbf{x}$ 。把源方差规范为 1 后，白化空间中的混合矩阵正交，剩下的问题是在球面上寻找独立方向。

图5.3说明白化后为何还需要解混。左图的协方差已经是单位阵，但给定靠近边缘的 x_1 时， x_2 可取的区间随之改变，两个分量仍有依赖。旋转回右图的源坐标后，均匀方形的联合分布才分解为两个一维均匀分布。协方差在旋转前后相同，区分这些方向必须使用更完整的分布信息。




图 5.3 白化与独立源恢复的区别。设 s_1, s_2 独立且均服从 $\mathcal{U}[-\sqrt{3}, \sqrt{3}]$, $\mathbf{R}(\theta)$ 为逆时针旋转矩阵。左图为 $\mathbf{x} = \mathbf{R}(30^\circ)\mathbf{s}$, 右图为逆旋转恢复的 $\mathbf{s}$; 两者协方差均为 $\mathbf{I}_2$, 只有右侧所示坐标对应独立源。实线轮廓为总体支持域, 圆点为确定性格点, 虚线箭头为解混方向。图为无量纲构造示意, 未运行 ICA 优化; 该方形解混本身不减少维数。

FastICA 用光滑非二次函数 G 构造要最大化的非高斯性对比量。对单位方向 $\mathbf{u}$, 白化保证 $\mathbf{u}^\top \tilde{\mathbf{x}}$ 的方差为 1, 因而可与标准高斯变量 ν 比较:

$$J_G(\mathbf{u}) = [\mathbb{E}G(\mathbf{u}^\top \tilde{\mathbf{x}}) - \mathbb{E}G(\nu)]^2, \quad \|\mathbf{u}\|_2 = 1. \quad (5.12)$$

这是前述负熵的近似对比目标, 不是任意 G 下的精确负熵。令 $\mathbf{g} = G'$; 当括号内的差非零, 且期望与微分可交换时, J_G 在单位球面上的驻点也满足 $\mathbb{E}G(\mathbf{u}^\top \tilde{\mathbf{x}})$ 的约束驻点方程

$$\mathbf{a}(\mathbf{u}) := \mathbb{E}[\tilde{\mathbf{x}}\mathbf{g}(\mathbf{u}^\top \tilde{\mathbf{x}})] = \beta \mathbf{u}, \quad \beta = \mathbf{u}^\top \mathbf{a}(\mathbf{u}).$$

这里 β 是单位范数约束的乘子。为近似求解该方程, 在当前点固定 β , 把其 Jacobian 中的 $\mathbb{E}[\tilde{\mathbf{x}}\tilde{\mathbf{x}}^\top \mathbf{g}'(\mathbf{u}^\top \tilde{\mathbf{x}})]$ 近似为 $c\mathbf{I}$, 其中 $c = \mathbb{E}\mathbf{g}'(\mathbf{u}^\top \tilde{\mathbf{x}})$ 。白化提供单位协方差, 但这个加权矩阵近似并不是白化自动推出的恒等式。若 $c - \beta \neq 0$, 相应的近似 Newton 步为

$$\mathbf{u} - \frac{\mathbf{a}(\mathbf{u}) - \beta \mathbf{u}}{c - \beta} = \frac{c\mathbf{u} - \mathbf{a}(\mathbf{u})}{c - \beta}.$$

ICA 方向允许符号翻转, 归一化又会消去非零标量, 因此可直接用 $\mathbf{a}(\mathbf{u}) - c\mathbf{u}$ 更新方向。这就得到 FastICA 的固定点形式: 给定当前单位方向 $\mathbf{u}^{(i)}$, 用

样本平均代替期望计算

$$\begin{aligned} \mathbf{v}^{(t+1)} &= \frac{1}{n} \sum_{i=1}^n \tilde{\mathbf{x}}_i g((\mathbf{u}^{(t)})^\top \tilde{\mathbf{x}}_i) \\ &\quad - \left[\frac{1}{n} \sum_{i=1}^n g'((\mathbf{u}^{(t)})^\top \tilde{\mathbf{x}}_i) \right] \mathbf{u}^{(t)}, \\ \mathbf{u}^{(t+1)} &= \mathbf{v}^{(t+1)} / \|\mathbf{v}^{(t+1)}\|_2. \end{aligned} \quad (5.13)$$

常见选择有 $G(u) = \log \cosh u$ 或 $G(u) = u^4/4$, 分别给出 $g(u) = \tanh u$ 或 $g(u) = u^3$; 四次矩形式对极端值更敏感。提取多个成分时, 可逐个对已得方向正交化, 也可对整组方向做对称正交化。停止准则通常检查方向变化, 并允许符号翻转¹⁵。

FastICA 的快速收敛结论依赖源分布、对比函数和初始化等条件; 若更新向量接近零, 需重新初始化或调整设置。前述信息最大化路线 Infomax 通过选择输出非线性并最大化输出熵学习解混, 适合梯度更新; JADE 则联合对角化四阶累积量矩阵。它们使用的信息与数值开销不同, 不能只按迭代次数比较效率。

¹⁵ A. Hyvarinen, *Fast and robust fixed-point algorithms for independent component analysis* In IEEE Transactions on Neural Networks, 1999, vol. 10, no. 3, pp. 626–634

5.1.3.3 小结

ICA 把去相关推进到独立源识别, 但独立性是模型前提和估计目标, 不是任意数据上的保证。标准方形 ICA 本身不减少维数; 只有先截断白化空间, 或采用源数少于通道数的模型, 才同时完成压缩。源数多于通道数才是欠定混合, 通常需要稀疏性等额外条件。非线性混合、相关源、多个高斯源和较强噪声, 也会改变可识别性与适用算法。

5.1.4 非负矩阵分解 (NMF)

词频、光谱强度和像素亮度天然非负。若表示允许任意正负抵消, 一个基向量的物理含义可能难以解释。**非负矩阵分解** (nonnegative matrix factorization, NMF) 要求系数与基均非负, 使重构由若干成分相加得到。

非负分解的早期工作来自不同问题。Paatero 与 Tapper 在 1994 年的正矩阵分解中, 根据环境测量各项误差的大小加权残差, 并在拟合时直接施加非负约束¹⁶。Lee 与 Seung 在 1999 年则从整体与部件的感知关系出发, 用人脸和文本展示加性表示可以学出怎样的组成成分¹⁷。前者强调测量误差与物理约束, 后者强调表示的组成方式; 这也说明同样的非负结构可以配合不同损失和应用假设。

5.1.4.1 模型结构

对非负矩阵 $\mathbf{X} \in \mathbb{R}_+^{n \times d}$, 求

$$\mathbf{X} \approx \mathbf{WH}, \quad \mathbf{W} \in \mathbb{R}_+^{n \times k}, \quad \mathbf{H} \in \mathbb{R}_+^{k \times d}. \quad (5.14)$$

本小节 $\mathbf{W}$ 表示样本系数, 区别于 PCA 中的正交基矩阵; 其第 i 行就是第 i 个样本的表示, $\mathbf{H}$ 各行为共享基。例如文档可由若干主题词模式相加近似, 光谱可由若干成分谱相加近似。非负性禁止抵消, 但不自动保证基局部化、系数稀疏或主题具有人工可读的语义。

图5.4用两个固定的非负基说明逐元素相加。把九个像素按行展开, 令 $\mathbf{H}$ 两行为横条基与竖条基的转置, 系数 (0.6, 1.0) 就生成右侧图案。两条基在中心像素都有贡献, 所以中心值为 1.6。固定字典后, 两个系数足以重构这个特定图案; 一般观测仍可能有近似误差, 字典本身也需要存储。




图 5.4 两个非负基的加性重构。左侧两幅 3×3 栅格分别给出未加权的横条、竖条基, 外侧系数为 0.6 与 1.0; 右侧为逐像素加权和, 粗框中心格等于 $0.6 + 1.0 = 1.6$ 。数值无量纲, 本构造恰好精确重构, 不表示 NMF 总能学出这样的部件或保证唯一分解。

连续观测常使用 $\frac{1}{2} \|\mathbf{X} - \mathbf{WH}\|_F^2$, 对应固定方差高斯残差的似然形式。对非负计数, 可使用广义 KL 散度 (也称 I 散度) 作为目标:

$$\mathcal{L}_{\text{KL}} = \sum_{i,j} \left[\mathbf{X}_{i,j} \log \frac{\mathbf{X}_{i,j}}{(\mathbf{WH})_{i,j}} - \mathbf{X}_{i,j} + (\mathbf{WH})_{i,j} \right]. \quad (5.15)$$

约定 $0 \log(0/u) = 0$; 若 $\mathbf{X}_{i,j} > 0$ 而重构为零, 损失为无穷大。对于条件独

¹⁶ P. Paatero, U. Tapper, *Positive matrix factorization: A non-negative factor model with optimal utilization of error estimates of data values* In *Environmetrics*, 1994, vol. 5, no. 2, pp. 111–126

¹⁷ D. D. Lee, H. S. Seung, *Learning the parts of objects by non-negative matrix factorization* In *Nature*, 1999, vol. 401, no. 6755, pp. 788–791

立的 Poisson 计数, 这与负对数似然相差一个仅依赖数据的常数; 过度离散的计数则可能需要其他观测模型。

一般 NMF 不唯一。即使只考虑正对角矩阵 D , $WH = (WD)(D^{-1}H)$ 就显示了尺度自由度, 成分排列也不唯一。稀疏、平滑或归一化约束可以减少歧义, 但仍不能无条件保证唯一分解。

5.1.4.2 参数学习

两个因子联合优化非凸, 固定一个时, 另一个的平方误差子问题是带非负约束的凸问题。Lee 与 Seung 的乘法更新利用非负比率维持可行性。以下所有乘除均逐元素进行, 两个更新顺序执行¹⁸。

$$\begin{aligned} W &\leftarrow W \odot \frac{XH^T}{WHH^T}, \\ H &\leftarrow H \odot \frac{W^T X}{W^T W H}. \end{aligned} \quad (5.16)$$

在正初始化与更新有定义等条件下, 可用辅助函数证明目标单调不减。由于目标非负, 目标值序列收敛; 这一步并不等于已证明参数收敛到局部极小或全局最优。零元素还可能一直锁在零上, 使基本更新难以满足最优性条件。实现中须处理零分母, 并检查约束下的梯度残差和多次初始化结果。

投影梯度用 $\max(0, \cdot)$ 将更新投回非负区域; 交替非负最小二乘则更充分地求解各子问题。HALS 或坐标下降逐个调整基与系数, 适合利用稀疏矩阵结构。求解速度取决于损失、稀疏性、停止精度与初始化, 不能从目标单调性推出某个算法普遍最快¹⁹。

基 H 固定后, 新样本表示通过非负最小二乘或相应 KL 目标求得。例如平方误差下求 $\min_{w \geq 0} \|x - H^T w\|_2^2$, 通常不是简单乘一个固定投影矩阵。普通稠密平方误差更新的主要乘法约需 $O(ndk)$; 训练总成本还要乘迭代次数。

5.1.4.3 小结

NMF 适用于有加性解释的非负数据, 代价是非凸学习与通常不唯一的表示。低秩时, PCA 与 NMF 都一般存在重构误差; PCA 的正交性并不意味着压缩后无损。若数据经过中心化出现负值, 直接平移到非负区间也会改变分解含义, 应先确认这种预处理是否符合任务。

在合适的归一化和计数似然约定下, 采用式(5.15)广义 KL 目标的 NMF 与概率隐语义索引优化同一个目标函数, 但两者的更新算法并不相同²⁰。潜在狄利克雷分配进一步为文档主题比例引入先验, 不能仅视为换个名称的 NMF²¹。非负张量分解处理多轴数据, 凸 NMF、正交 NMF、稀疏 NMF 和深度 NMF 分别改变基的构成、成分关系、稀疏结构与层次组织。它们

¹⁸ D. D. Lee, H. S. Seung, *Algorithms for Non-negative Matrix Factorization* In *Advances in Neural Information Processing Systems*, 2000, pp. 556–562

¹⁹ C.-J. Lin, *Projected Gradient Methods for Nonnegative Matrix Factorization* In *Neural Computation*, 2007, vol. 19, no. 10, pp. 2756–2779

²⁰ C. Ding, T. Li, W. Peng, *On the Equivalence between Non-negative Matrix Factorization and Probabilistic Latent Semantic Indexing* In *Computational Statistics & Data Analysis*, 2008, vol. 52, no. 8, pp. 3913–3927

²¹ D. M. Blei, A. Y. Ng, M. I. Jordan, *Latent Dirichlet Allocation* In *Journal of Machine Learning Research*, 2003, vol. 3, pp. 983–1022

增加的约束应由应用中的可解释性要求支持。

5.1.5 稀疏编码与字典学习

一个图像块可能只包含少量边缘，却需要从许多位置和方向中选择这些边缘。因此，与其只准备少数基向量，也可以准备很大的候选库，而要求每次只用其中几个。**稀疏编码**（sparse coding）在给定字典中寻找少数活跃系数，**字典学习**（dictionary learning）则进一步从样本中学习这些共享基。

Olshausen 与 Field 在 1996 年关心的是，自然图像的统计结构能否解释初级视觉皮层神经元响应的局部性、方向选择性和空间频率选择性。他们检验了稀疏线性编码能否学出同时具有这些性质的一组基，并将其与小波表示比较²²。这项工作把视觉神经科学与信号表示联系起来；计算结果与感受野相似，并不能证明大脑执行了完全相同的学习算法。

²² B. A. Olshausen, D. J. Field, *Emergence of simple-cell receptive field properties by learning a sparse code for natural images* In *Nature*, 1996, vol. 381, no. 6583, pp. 607–609

5.1.5.1 模型结构

记字典为 $\mathbf{D} \in \mathbb{R}^{d \times p}$ ，列 $\mathbf{d}_j$ 称为字典原子；本小节用 p 表示原子数，允许 $p > d$ ，此时字典过完备。样本满足 $\mathbf{x}_i \approx \mathbf{D}\boldsymbol{\alpha}_i$ ，系数 $\boldsymbol{\alpha}_i \in \mathbb{R}^p$ 多数为零。常用学习目标为

$$\min_{\mathbf{D}, \{\boldsymbol{\alpha}_i\}} \sum_{i=1}^n \left[\frac{1}{2} \|\mathbf{x}_i - \mathbf{D}\boldsymbol{\alpha}_i\|_2^2 + \lambda \|\boldsymbol{\alpha}_i\|_1 \right], \quad (5.17)$$

约束 $\|\mathbf{d}_j\|_2 \leq 1 \quad (j = 1, \dots, p).$

列范数约束防止把字典无限放大、系数相应缩小，以任意降低 ℓ_1 惩罚而不改变重构。与 NMF 不同，这里不要求非负；与 PCA 不同，这里不要求正交，表示长度甚至可以超过原维数。

固定一个含 s 个原子的支持集，重构位于至多 s 维的线性子空间；允许支持集变化，就得到许多子空间的并。这解释了“稀疏性代替低维性”的含义，也说明它一般不是一张光滑低维流形。编码的活跃集合随输入改变，编码映射通常非线性。

5.1.5.2 参数学习

固定字典后，各样本独立求解 Lasso 型问题，可采用坐标下降、LARS 或近端梯度。以单一样本为例，若 $L \geq \|\mathbf{D}^\top \mathbf{D}\|_2$ 且 $L > 0$ ，ISTA 更新为

$$\boldsymbol{\alpha}^{(t+1)} = \mathcal{S}_{\lambda/L} \left(\boldsymbol{\alpha}^{(t)} + L^{-1} \mathbf{D}^\top (\mathbf{x} - \mathbf{D}\boldsymbol{\alpha}^{(t)}) \right). \quad (5.18)$$

梯度步减小重构误差，软阈值步对应 ℓ_1 惩罚的近端映射。FISTA 加入加速外推，在凸子问题的标准条件下改善目标值收敛率；这一保证针对固定字典，不直接覆盖字典和编码的联合优化²³。

固定编码后，记 $\mathbf{A} = [\boldsymbol{\alpha}_1, \dots, \boldsymbol{\alpha}_n] \in \mathbb{R}^{p \times n}$ ，字典步最小化 $\frac{1}{2} \|\mathbf{X}^\top - \mathbf{D}\mathbf{A}\|_F^2$

²³ A. Beck, M. Teboulle, *A Fast Iterative Shrinkage-Thresholding Algorithm for Linear Inverse Problems* In *SIAM Journal on Imaging Sciences*, 2009, vol. 2, no. 1, pp. 183–202

并满足列范数约束。MOD 从无约束最小二乘解 $\mathbf{X}^T \mathbf{A}^\dagger$ 出发更新方向；简单归一化是常用实现，但一般不等于精确求解带耦合列约束的子问题。需要严格下降时，应使用适当的约束求解或可验证更新。

K-SVD 通常配合 $\|\alpha_i\|_0 \leq s$ 的稀疏度约束：更新某个原子时，先去掉其他原子的贡献，仅保留使用该原子的样本，再对残差作秩一 SVD，同时更新原子及其活跃系数。这不同于直接精确求解式(5.17)的 ℓ_1 目标²⁴。

在线字典学习逐次处理小批样本，并积累编码二阶统计量与观测交叉统计量，以近似更新字典。它减少了反复扫描全部数据的开销，但达到给定精度的成本仍取决于原子数、稀疏求解和更新次数，不能仅由一次遍历写成无条件的 $O(n)$ 总成本²⁵。

5.1.5.3 小结

稀疏编码用少量活跃原子描述样本，适合去噪、修复和具有可组合模式的信号表示。新样本仍须推断系数，因此使用成本与线性投影不同。压缩感知进一步研究稀疏信号何时可由少量线性测量恢复，需要测量矩阵满足受限等距或相关条件；稀疏性本身并不足以保证恢复。

判别式字典把标签信息加入学习，结构稀疏规定哪些原子应共同出现，卷积稀疏编码共享不同位置的滤波器。稀疏自编码器和层次特征学习也吸收了类似的表示约束，但不能由滤波器外观相近就推出算法或理论等价。稀疏编码在本章中的位置，是补充线性组合表示这一方向，而不是把高维稀疏向量重新称为低维坐标。

5.1.6 随机投影 (Random Projection)

前述方法需要根据数据选择投影或字典。对于维数极高、必须立即处理的流式数据，能否预先固定一个映射，仍近似保留样本间的欧氏距离？**随机投影** (random projection) 从指定分布抽取矩阵，再用同一个矩阵变换所有样本。Johnson-Lindenstrauss 引理说明，对任意预先给定的有限点集，这种构造能够以较高概率同时近似保距²⁶。

保距保证解决了表示是否存在的问题，数据库应用还要求映射容易生成和计算。Achlioptas 在 2003 年为此构造离散随机矩阵，使投影可以化为对属性的加减、聚合与统一缩放²⁷。这种发展保留了不依赖数据拟合的几何保证，改变的是计算所需的操作。

5.1.6.1 模型结构

令 $\mathbf{\Pi} \in \mathbb{R}^{k \times d}$ ，编码为 $\mathbf{z} = \mathbf{\Pi} \mathbf{x}$ 。最直接的选择是独立采样 $\Pi_{i,j} \sim \mathcal{N}(0, 1/k)$ 。对任意固定 $\mathbf{x}$ ，

$$\mathbb{E}_{\mathbf{\Pi}} \|\mathbf{\Pi} \mathbf{x}\|_2^2 = \|\mathbf{x}\|_2^2.$$

²⁴ M. Aharon, M. Elad, A. Bruckstein, *K-SVD: An Algorithm for Designing Overcomplete Dictionaries for Sparse Representation* In IEEE Transactions on Signal Processing, 2006, vol. 54, no. 11, pp. 4311–4322

²⁵ J. Mairal, F. Bach, J. Ponce, G. Sapiro, *Online Dictionary Learning for Sparse Coding* In Proceedings of the 26th Annual International Conference on Machine Learning, 2009, pp. 689–696

²⁶ W. B. Johnson, J. Lindenstrauss, *Extensions of Lipschitz mappings into a Hilbert space* In Conference in Modern Analysis and Probability, 1984, pp. 189–206

²⁷ D. Achlioptas, *Database-friendly random projections: Johnson-Lindenstrauss with binary coins* In Journal of Computer and System Sciences, 2003, vol. 66, no. 4, pp. 671–687

平均保范数还不够；要让同一次采样同时适合很多样本，必须控制偏离均值的尾概率。

稀疏构造可以降低乘法和存储开销。例如 Achlioptas 矩阵的元素以 $1/6$ 概率取 $\sqrt{3/k}$ 、以 $1/6$ 概率取 $-\sqrt{3/k}$ ，其余取零，仍可建立相应的集中界。Li、Hastie 与 Church 研究了更稀疏的构造，但进一步稀疏化的误差分析与输入分量集中程度有关，不能只凭二阶矩匹配就宣称任意稀疏率都有相同保证²⁸。

快速 Johnson–Lindenstrauss 变换利用随机符号、Hadamard 变换与后续抽样或稀疏映射。其结构化变换部分约需 $O(d \log d)$ ，总体代价还包含输出维数及精度相关项。它与直接存放 kd 个高斯元素的实现具有不同的内存、算术和输入尺寸要求²⁹。

5.1.6.2 参数学习

随机投影没有数据拟合步骤，但仍有需要选择的超参数：目标维数 k 、矩阵分布及其稀疏程度。矩阵确定以后，训练与新样本共享同一个映射；稠密投影每个样本需 $O(kd)$ 次运算。分布式使用时，共享种子还需同时固定伪随机数实现与矩阵生成顺序，才能重现同一映射。

下述定理给出 k 与误差、点数、失败概率之间的关系。理论维数可能相当保守；若它已经超过 d ，这个上界就没有给出实际压缩收益。工程中可以在训练或验证数据上测量距离失真，再决定是否采用较小的 k 。先随机压缩到中等维数、再做 PCA 或最近邻搜索，也是一种可比较的方案，但下游效果仍须独立验证。

主线阅读可直接使用定理中的维数尺度和失败概率，把它作为候选 k 的上界依据。进阶证明说明单个差向量的卡方集中怎样经联合界扩展到全部训练点对；因此，结论的对象是预先固定的有限集合，而不是投影后自适应选择的任意查询。

5.1.6.3 理论分析

收敛性分析 随机投影无需拟合或迭代。这里的收敛考察投影维数增加时距离误差的概率集中；定理给出一次随机采样同时保留全部训练点对距离的条件。

定理 5.2 高斯随机投影的 Johnson–Lindenstrauss 保证 给定 $n \geq 2$ 个固定点 $\mathbf{x}_1, \dots, \mathbf{x}_n \in \mathbb{R}^d$ ，取 $0 < \varepsilon < 1$ 、 $0 < \delta < 1$ 。若

$$k \geq \frac{8}{\varepsilon^2} \log \frac{n(n-1)}{\delta},$$

²⁸ P. Li, T. J. Hastie, K. W. Church, *Very sparse random projections* In Proceedings of the 12th ACM SIGKDD international conference on Knowledge discovery and data mining, 2006, pp. 287–296

²⁹ N. Ailon, B. Chazelle, *The Fast Johnson–Lindenstrauss Transform and Approximate Nearest Neighbors* In SIAM Journal on Computing, 2009, vol. 39, no. 1, pp. 302–322

且 $\Pi_{r,j}$ 独立服从 $\mathcal{N}(0, 1/k)$, 则以至少 $1 - \delta$ 的概率, 对全部样本对同时有

$$\begin{aligned} (1 - \varepsilon) \|\mathbf{x}_i - \mathbf{x}_j\|_2^2 &\leq \|\Pi(\mathbf{x}_i - \mathbf{x}_j)\|_2^2 \\ &\leq (1 + \varepsilon) \|\mathbf{x}_i - \mathbf{x}_j\|_2^2. \end{aligned}$$

证明. 固定单位向量 $\mathbf{u}$, 随机变量 $Y = k \|\Pi \mathbf{u}\|_2^2$ 服从 k 自由度的卡方分布, 其矩母函数为 $\mathbb{E} e^{tY} = (1 - 2t)^{-k/2}$, $t < 1/2$. 对上尾应用 Chernoff 方法并取 $t = \varepsilon/(2(1 + \varepsilon))$, 有

$$\mathbb{P}(Y \geq k(1 + \varepsilon)) \leq \exp\{-k[\varepsilon - \log(1 + \varepsilon)]/2\}.$$

下尾采用负 t 可得 $\exp\{-k[-\varepsilon - \log(1 - \varepsilon)]/2\}$. 在 $0 < \varepsilon < 1$ 内, 两者均不超过 $\exp(-k\varepsilon^2/8)$, 故

$$\mathbb{P}(|\|\Pi \mathbf{u}\|_2^2 - 1| > \varepsilon) \leq 2e^{-k\varepsilon^2/8}.$$

对每一非零差向量归一化后使用这个界; 重合点对自动满足要求。用联合界控制至多 $n(n-1)/2$ 个事件, 得到至少一对失败的概率不超过

$$n(n-1)e^{-k\varepsilon^2/8} \leq \delta.$$

联合界不要求不同点对的事件独立。 ■

JL 的 $\varepsilon^{-2} \log n$ 维数尺度在相应参数区间内还有匹配的下界³⁰。若希望失败概率至多 $1/n$, 上述证明给出的简洁充分条件是 $k \geq 24 \log n / \varepsilon^2$: 此时 $n(n-1)e^{-k\varepsilon^2/8} \leq n^2 n^{-3} = 1/n$ 。常数取决于集中界的具体形式; 关键是 k 随点数对数增长, 上界不直接依赖原始维数 d 。

³⁰ K. G. Larsen, J. Nelson, *Optimality of the Johnson-Lindenstrauss Lemma* In Proceedings of the 58th IEEE Annual Symposium on Foundations of Computer Science, 2017, pp. 633–638

泛化分析 保证针对投影之前固定的有限点集, 并非同时保证 $\mathbb{R}^d$ 中的所有向量。若 $k < d$, 投影必有非零核空间, 那里某些距离被压成零。对独立于投影预先指定的新查询点, 可将其加入有限集合重新计算联合界; 对观察投影后自适应选出的任意查询, 则需要额外分析。

5.1.6.4 小结

随机投影提供了无需先拟合数据的距离近似, 适合流式处理和超高维预处理。它保留的是指定度量下的有限点集几何, 不会自动筛选预测相关特征, 也不保证能压到二维而仍有很小失真。局部敏感哈希、压缩感知和随机化线性代数都使用相关随机构造, 但各自要求的碰撞概率、稀疏集合保距或子空间逼近保证有所不同。随机 Fourier 特征近似平移不变核, 特征哈希

依赖哈希与符号映射；这些方法与随机投影相关，也不能一概视为同一个 JL 矩阵。

5.1.7 核主成分分析 (Kernel PCA)

也可以先改变特征,再保留方差。**核主成分分析**(kernel principal component analysis, Kernel PCA) 在非线性特征空间中做 PCA, 只通过核函数计算内积, 无须显式列出特征。Schölkopf、Smola 与 Müller 在 1998 年给出了这一核特征值方法³¹。

³¹ B. Schölkopf, A. Smola, K.-R. Müller, *Nonlinear Component Analysis as a Kernel Eigenvalue Problem* In Neural Computation, 1998, vol. 10, no. 5, pp. 1299–1319

5.1.7.1 模型结构

直接使用第1.2.1.2节的 Hilbert 特征空间 $\mathcal{H}$ 、映射 ϕ 与正定核 K ；训练核矩阵及中心化矩阵 $\mathbf{H}$ 沿用第1.2.1.4节。本节要求在该特征空间保留方差, 核 SVM 使用的分类间隔并不是这里的目标。

按简介中的训练特征中心化规则, 记

$$\bar{\phi} = \frac{1}{n} \sum_i \phi(x_i), \quad \phi_c(x) = \phi(x) - \bar{\phi}.$$

经验协方差算子作用于方向 $\mathbf{v} \in \mathcal{H}$ 的方式为

$$\hat{\mathbf{C}}\mathbf{v} = \frac{1}{n} \sum_i \phi_c(x_i) \langle \phi_c(x_i), \mathbf{v} \rangle_{\mathcal{H}}. \quad (5.19)$$

若 $\hat{\mathbf{C}}\mathbf{v} = \lambda^C \mathbf{v}$ 且 $\lambda^C > 0$, 由右边可知 $\mathbf{v}$ 在中心化训练特征张成的空间中; 零特征值方向不必满足此结论。

因此写 $\mathbf{v}_\ell = \sum_i (\alpha_\ell)_i \phi_c(x_i)$ 。令 $\mathbf{K}_c = \mathbf{H}\mathbf{K}\mathbf{H}$, 代回协方差特征方程得到核特征值 $\lambda_\ell^K = n\lambda_\ell^C$ 。

5.1.7.2 参数学习

令 $\mathbf{u}_\ell$ 是中心化核矩阵的欧氏单位特征向量。正确的归一化关系是

$$\begin{aligned} \mathbf{K}_c \mathbf{u}_\ell &= \lambda_\ell^K \mathbf{u}_\ell, \quad \|\mathbf{u}_\ell\|_2 = 1, \\ \alpha_\ell &= \frac{\mathbf{u}_\ell}{\sqrt{\lambda_\ell^K}}, \\ \|\mathbf{v}_\ell\|_{\mathcal{H}}^2 &= \alpha_\ell^\top \mathbf{K}_c \alpha_\ell = 1. \end{aligned} \quad (5.20)$$

训练点在方向 $\mathbf{v}_\ell$ 上的投影构成一整列坐标:

$$\mathbf{Z}_{:, \ell} = \mathbf{K}_c \alpha_\ell = \sqrt{\lambda_\ell^K} \mathbf{u}_\ell = \lambda_\ell^K \alpha_\ell. \quad (5.21)$$

单位向量 $\mathbf{u}_\ell$ 和展开系数 α_ℓ 的归一化不同, 训练坐标是 $\sqrt{\lambda_\ell^K} \mathbf{u}_\ell$, 而不是 $\sqrt{\lambda_\ell^K} \alpha_\ell$ 。

核选择会先决定哪些变化值得保留。图5.5刻意取 $\phi(\mathbf{x}) = \|\mathbf{x}\|_2^2$, 只观察半径平方; 核 $K(\mathbf{x}, \mathbf{y}) = \phi(\mathbf{x})\phi(\mathbf{y})$ 因此正半定。两个圆各取相同数量的点, 特征均值就是 $(1+4)/2 = 2.5$, 中心化坐标为 -1.5 和 1.5 。这里核 PCA 保留了径向差异, 却无法恢复已经被特征映射丢掉的角度信息。




图 5.5 由核选择保留量的构造例子。左图在半径为 1, 2 的圆上各取 16 个等角度样本, 圆点与方点区分两圈。所示特制核对应标量特征 $\phi(\mathbf{x}) = \|\mathbf{x}\|_2^2$, 中心化核矩阵秩为 1; 选择图示主轴方向, 核 PCA 坐标为 ± 1.5 。右侧每个标记表示 16 点重合, 坐标无量纲。此结果依赖所选核, 不能推广为任意高斯核或多项式核的输出。

对新样本 $\mathbf{x}$, 仍应使用训练特征均值。定义 $\mathbf{k}(\mathbf{x})_i = K(\mathbf{x}_i, \mathbf{x})$, 其完整中心化公式与投影公式为

$$\begin{aligned} \mathbf{k}_c(\mathbf{x}) &= \mathbf{k}(\mathbf{x}) - \frac{1}{n} \mathbf{K} \mathbf{1} \\ &\quad - \frac{1}{n} \mathbf{1} \mathbf{1}^\top \mathbf{k}(\mathbf{x}) + \frac{1}{n^2} \mathbf{1} \mathbf{1}^\top \mathbf{K} \mathbf{1}, \\ z_\ell(\mathbf{x}) &= \alpha_\ell^\top \mathbf{k}_c(\mathbf{x}). \end{aligned} \quad (5.22)$$

两个减项扣除相对于训练均值的内积, 末项补回均值自内积; 仅对新核向量减去自身均值并不充分, 加入新点重算均值则会改变已学映射。

常用核构造约需 $O(n^2 d)$, 稠密谱分解为 $O(n^3)$, 存储为 $O(n^2)$ 。Nyström 用代表列近似核矩阵; 随机 Fourier 特征为合适的平移不变核构造有限维特征, 再做线性 PCA。两者都需评价近似误差, 后者不适用于任意核。

高斯带宽过大使核值接近, 中心化后信号很弱; 过小使核矩阵接近单位矩阵, 难以分辨主方向。距离中位数可提供初始尺度, 再按任务验证。服务于监督任务时, 中心化与主成分都应只在训练折拟合。

5.1.7.3 理论分析

收敛性分析 固定正定核后, 核 PCA 的经验目标仍可全局求解; 数值误差来自核矩阵近似与谱求解。它也与从点间距离恢复坐标的方法有关: 后

文第5.2.1节定义经典 MDS 后, 定理5.4将说明, 核诱导距离的经典 MDS 与中心化核 PCA 给出相同的训练坐标。这个联系只针对相应的特征距离, 不把后文的局部重构或图平滑目标等同于方差最大化。

泛化分析 固定有界核、可分特征空间和独立同分布采样下, 经验协方差算子随样本增加逼近总体对象; 目标谱与其余谱之间有正间隔时, 主子空间也可稳定逼近³²。核随数据变化或谱隙趋零时, 需要另作分析。

样本外公式不保证分布之外的表示质量, 新点与训练点的核值可能几乎一致。截断特征也未必有对应的输入原像, 原始空间重构需另行求解。

³² G. Blanchard, O. Bousquet, L. Zwald, *Statistical Properties of Kernel Principal Component Analysis In Machine Learning*, 2007, vol. 66, no. 2–3, pp. 259–294

5.1.7.4 小结

核 PCA 先选特征几何, 再选主方向。它保留谱求解与明确的样本外公式, 但结果依赖有效核、训练中心化、带宽与谱隙, 并非无条件恢复流形。

5.1.8 模型对比与总结

同样使用矩阵计算, 并不意味着线性与核方法保留了相同信息。表5.1将训练目标与新样本编码放在一起比较: 前者决定学到了什么, 后者决定表示能否经济地复用。ICA 的标准方形形式保留维数, 过完备稀疏编码甚至增加坐标数; 本节共同范围是线性投影与线性组合表示, 而非每种方法都必然输出更短的向量。

方法	主要目标与约束	新样本的表示	典型边界
PCA	正交投影下保留方差	中心化后矩阵乘法	对尺度、异常值敏感
CCA	配对视图的相关性最大	两侧分别线性投影	需配对观测, 易过拟合相关性
ICA	独立源的线性解混	白化及解混乘法	独立性、非高斯性与可识别性
NMF	非负基与非负系数重构	非负约束推断	非凸、通常不唯一
稀疏编码	少量原子重构观测	稀疏优化	可为高维编码, 需控制推断成本
随机投影	随机矩阵近似保距	固定矩阵乘法	维数、误差与失败概率的权衡
核 PCA	特征空间方差	训练中心化核投影	核几何、样本展开与原空间重构

表 5.1 线性投影与线性组合方法的比较。目标成立均依赖各小节的具体条件; “新样本可编码”不等于编码具有统计泛化保证。

求解方式也呈现不同取舍。PCA 与 CCA 可化为谱分解, ICA 用非高斯对比函数学习, NMF 与字典学习需要交替优化; 随机投影只生成矩阵。对于迭代方法, 稠密矩阵乘法的单步代价不等于训练总成本; 稀疏结构、所需精度和迭代次数都可能改变比较结果。NMF 和字典学习的基具有可追溯性, 但成分是否对应可解释概念, 还须由数据和任务验证。

当响应或类别标签可用时, 也可以直接寻找与预测目标有关的方向。第2.1.2节中的 PCR 先按输入方差构造主成分, PLS 则让响应参与成分构造; 第3.1.1.4节中的线性判别分析比较类间与类内散度。切片逆回归利用

$E[\mathbf{x} | y]$ 的变化, 在相应线性条件与非退化条件下恢复有效降维方向, 却可能遗漏条件均值无法显示的对称响应结构³³。这些监督目标都不同于 PCA 只保留观测方差的准则。

监督降维构造新的方向, 特征选择则保留原坐标的子集; 二者可以组合, 却不能因输出都变短就混为同一问题。用于预测时, 应把响应参与的方向学习、特征选择和后续预测器全部限制在训练折内, 并用相同下游风险比较无监督表示、监督表示与不降维基线。

因子分析为线性组合增加特征特异的噪声模型, 将在第5.4节展开; 多维缩放从点间距离出发, 在欧氏距离输入下与 PCA 联系起来, 是下一节的入口。选择方法时, 应先确定需要保留方差、视图相关、独立源、非负部件、稀疏支持还是点对距离, 再比较求解代价。对于弯曲流形, 仅改变线性基通常不足以恢复内在几何, 需要改用非线性关系。

5.2 基于距离的降维

有些数据给出的是对象间差异, 而不是可以直接投影的特征。这里采用多维缩放, 从差异恢复坐标; 它不要求输入来自流形。这个距离入口位于线性与核方法之后, 再连接下一节依据局部邻域构造的几何表示。

5.2.1 多维缩放 (MDS)

感知差异评分可以描述对象间的关系, 却不提供坐标。**多维缩放** (multidimensional scaling, MDS) 为这些对象安排低维位置, 使其符合输入差异。Young 与 Householder 在 1938 年研究了距离对坐标的代数约束, 为这种坐标恢复提供了几何依据³⁴。

Torgerson 在 1952 年系统提出经典 MDS 时, 首先面对的是心理距离的测量问题: 刺激比较得到的差异甚至可能没有确定真实零点。他先讨论比较距离及其中未知加性常数的估计, 再讨论心理空间的维数和刺激坐标³⁵。这段历史提醒我们, 输入差异往往已经经过测量与建模; 原文中的加性常数问题, 也不同于下文对坐标或核矩阵作中心化。

5.2.1.1 模型结构

输入为对称差异矩阵 $\mathbf{D} \in \mathbb{R}^{n \times n}$, 满足 $\mathbf{D}_{i,j} \geq 0$ 、 $\mathbf{D}_{i,i} = 0$ 。欧氏距离、编辑距离、图距离或人工评分都可作为差异, 但未必能由低维欧氏距离实现。按照拟合准则, 可以区分三种 MDS。

³³ K.-C. Li, *Sliced Inverse Regression for Dimension Reduction* In Journal of the American Statistical Association, 1991, vol. 86, no. 414, pp. 316–327

³⁴ G. Young, A. S. Householder, *Discussion of a Set of Points in Terms of Their Mutual Distances* In Psychometrika, 1938, vol. 3, no. 1, pp. 19–22

³⁵ W. S. Torgerson, *Multidimensional Scaling: I. Theory and Method* In Psychometrika, 1952, vol. 17, no. 4, pp. 401–419

经典 MDS (classical MDS) 把距离平方转换为中心化内积。记 $\mathbf{1} \in \mathbb{R}^n$ 为全一向量, $\mathbf{I}_n$ 为单位矩阵, 定义

$$\begin{aligned} \mathbf{H} &= \mathbf{I}_n - \frac{1}{n} \mathbf{1} \mathbf{1}^\top, \\ \mathbf{D}_{i,j}^{\circ 2} &= (\mathbf{D}_{i,j})^2, \\ \mathbf{B} &= -\frac{1}{2} \mathbf{H} \mathbf{D}^{\circ 2} \mathbf{H}. \end{aligned} \quad (5.23)$$

上标 $\circ 2$ 表示逐元素平方。左右乘 $\mathbf{H}$ 分别减去列、行均值, 称为双中心化。对欧氏输入, $\mathbf{B}$ 是中心化坐标的 Gram 矩阵, 即两两内积组成的半正定矩阵。

设 $\mathbf{B}$ 的正特征值按降序排列为 $\lambda_1 \geq \dots \geq \lambda_r > 0$, 对应欧氏单位特征向量为 $\mathbf{u}_1, \dots, \mathbf{u}_r$ 。取 $k \leq r$, 经典 MDS 给出

$$\mathbf{Z} = \mathbf{U}_k \mathbf{\Lambda}_k^{1/2}, \quad \mathbf{Z}_{i,\ell} = \sqrt{\lambda_\ell} (\mathbf{u}_\ell)_i. \quad (5.24)$$

其中 $\mathbf{U}_k$ 按列收集特征向量, $\mathbf{\Lambda}_k$ 为相应对角矩阵。该解最小化的是内积残差, 通常称为 strain:

$$\min_{\substack{\mathbf{Z} \in \mathbb{R}^{n \times k} \\ \mathbf{Z}^\top \mathbf{1} = \mathbf{0}}} \left\| \mathbf{B} - \mathbf{Z} \mathbf{Z}^\top \right\|_F^2. \quad (5.25)$$

非欧氏输入可能产生负特征值。最优半正定秩约束近似舍去负谱, 只保留最大的至多 k 个正特征值, 此时通常不再精确保留输入距离。

若任务直接关心距离数值, 应使用以距离残差为目标的**度量 MDS** (metric MDS)。给定对称非负权重 $w_{i,j}$, 令 $\delta_{i,j}(\mathbf{Z}) = \|\mathbf{z}_i - \mathbf{z}_j\|_2$, 其常见应力 (stress) 目标为

$$S(\mathbf{Z}) = \sum_{i < j} w_{i,j} (\delta_{i,j}(\mathbf{Z}) - \mathbf{D}_{i,j})^2. \quad (5.26)$$

strain 惩罚内积误差, stress 惩罚距离误差, 二者并不等价。距离与中心化内积能相互转换, 不意味着两类残差平方和具有相同的最优近似。有些文献把经典 MDS 也称为 metric scaling, 这里按目标函数区分。

非度量 MDS (nonmetric MDS) 用于顺序比数值更可信的差异。它以非递减函数 $g(\mathbf{D}_{i,j})$ 替换式(5.26)中的目标距离, 同时估计 g 与 $\mathbf{Z}$, 并约束尺度以避免共同收缩到零。保序约束作用于拟合差异, 有限维嵌入未必实现全部严格次序; Kruskal 在 1964 年将这种顺序信息与应力准则结合³⁶。

5.2.1.2 参数学习

经典 MDS 通过双中心化和谱截断求解。平方 Frobenius 损失在正交特征方向上分解, 半正定约束排除负谱, 秩约束要求优先保留较大的正特征值。这给出全局最优解的谱表达, 实际特征分解仍需数值计算。

³⁶ J. B. Kruskal, *Multidimensional Scaling by Optimizing Goodness of Fit to a Nonmetric Hypothesis* In *Psychometrika*, 1964, vol. 29, no. 1, pp. 1–27

直接拟合 stress 通常需要迭代。以全部 $D_{i,j} > 0$ 的样本对为例, Sammon 映射采用

$$S_{\text{Sammon}}(\mathbf{Z}) = \frac{1}{\sum_{i < j} D_{i,j}} \sum_{i < j} \frac{(\delta_{i,j}(\mathbf{Z}) - D_{i,j})^2}{D_{i,j}}. \quad (5.27)$$

相同绝对误差在小距离处受到更大惩罚, 但这不保证全部邻域被保留。零差异需合并对象或另设权重³⁷。

应力型 MDS 可用梯度法、拟牛顿法或 SMACOF (scaling by majorizing a complicated function) 求解。SMACOF 在当前配置构造相切的二次上界, 再最小化上界; 若上界记为 Q , 其下降依据为

$$S(\mathbf{Z}^{(s+1)}) \leq Q(\mathbf{Z}^{(s+1)} | \mathbf{Z}^{(s)}) \leq Q(\mathbf{Z}^{(s)} | \mathbf{Z}^{(s)}) = S(\mathbf{Z}^{(s)}).$$

非度量情形可交替作保序回归和配置更新。目标非负且不增加, 因而目标值收敛, 但不保证全局最优, 也不保证迭代点总到达局部极小。通常用经典 MDS 初始化, 并比较多次运行; SMACOF 的构造与实现可参见 de Leeuw 与 Mair 的系统介绍³⁸。

稠密经典 MDS 需 $O(n^2)$ 存储、通常 $O(n^3)$ 的完整谱分解。部分谱求解或 Nyström 近似可减少计算; 标志点 MDS 先嵌入少量代表点, 再由到代表点的距离扩展。代表点覆盖不足仍会导致失真。

5.2.1.3 理论分析

收敛性分析 本段先区分固定数据上的谱最优性与应力优化, 再核对经典 MDS 和 PCA 处理同一批欧氏观测时的代数关系。经典 MDS 通过谱截断达到内积逼近目标的全局最优; 应力型 MDS 采用迭代算法时, 通常只能保证在适当条件下目标下降。

若 $\mathbf{D}$ 由任意坐标矩阵 $\mathbf{X}$ 的行间欧氏距离得到, 令 $\mathbf{X}_c = \mathbf{H}\mathbf{X}$, 则平移不改变 $\mathbf{D}$, 而双中心化给出

$$\mathbf{B} = \mathbf{H}\mathbf{X}\mathbf{X}^\top\mathbf{H} = \mathbf{X}_c\mathbf{X}_c^\top.$$

因此, 经典 MDS 应与中心化后的 $\mathbf{X}_c$ 所做的 PCA 比较, 而不是与未经中心化的数据或任意距离上的 PCA 比较:

主线结论是两种方法在相同 k 下共享中心化坐标的谱截断, 而不是任意 MDS 都等价于 PCA。进阶证明只展开欧氏距离平方经双中心化得到 Gram 矩阵这一步; 精确保距还要在定理后另查是否保留全部正谱。

定理 5.3 欧氏距离下经典 MDS 与 PCA 的关系 设 $\mathbf{X}^\top \mathbf{1} = \mathbf{0}$, $D_{i,j} = \|\mathbf{x}_i - \mathbf{x}_j\|_2$, 且 $1 \leq k \leq \text{rank}(\mathbf{X})$ 。若 PCA 与经典 MDS 选取相互对应

³⁷ J. W. Sammon Jr., *A Nonlinear Mapping for Data Structure Analysis* In IEEE Transactions on Computers, 1969, vol. 18, no. 5, pp. 401–409

³⁸ J. de Leeuw, P. Mair, *Multidimensional Scaling Using Majorization: SMACOF in R* In Journal of Statistical Software, 2009, vol. 31, no. 3, pp. 1–30

的前 k 个奇异方向, 则两者的坐标都可取为 $\mathbf{U}_k \boldsymbol{\Sigma}_k$, 从而得到相同的坐标 Gram 矩阵 $\mathbf{U}_k \boldsymbol{\Sigma}_k^2 \mathbf{U}_k^\top$ 。同一所选子空间内的坐标可相差右侧正交变换, 而 Gram 矩阵保持不变。

证明. 令 $\mathbf{a} \in \mathbb{R}^n$ 满足 $a_i = \|\mathbf{x}_i\|_2^2$ 。展开距离平方并双中心化, 得到

$$\begin{aligned} D^{\circ 2} &= \mathbf{a} \mathbf{1}^\top + \mathbf{1} \mathbf{a}^\top - 2\mathbf{X} \mathbf{X}^\top, \\ \mathbf{B} &= \mathbf{H} \mathbf{X} \mathbf{X}^\top \mathbf{H} = \mathbf{X} \mathbf{X}^\top. \end{aligned}$$

第一、第二项消失, 是因为 $\mathbf{H} \mathbf{1} = \mathbf{0}$; 末步使用样本已经中心化。对薄奇异值分解 $\mathbf{X} = \mathbf{U} \boldsymbol{\Sigma} \mathbf{V}^\top$, 有 $\mathbf{B} = \mathbf{U} \boldsymbol{\Sigma}^2 \mathbf{U}^\top$ 。MDS 坐标与 PCA 得分因而分别为

$$\mathbf{Z}_{\text{MDS}} = \mathbf{U}_k \boldsymbol{\Sigma}_k, \quad \mathbf{X} \mathbf{V}_k = \mathbf{U}_k \boldsymbol{\Sigma}_k.$$

在同一所选子空间内旋转坐标轴不改变 Gram 矩阵。 ■

这里的等价要求两种方法使用相同的保留维数 k , 等价对象是中心化训练坐标的秩为 k 的 Gram 矩阵及其诱导距离, 而不是原始特征轴。只有保留全部正特征值, 即 $k = \text{rank}(\mathbf{X}_c)$ 时, 低维坐标才精确保留输入的全部欧氏距离; 若 $k < \text{rank}(\mathbf{X}_c)$, 两种方法等价于同一个谱截断, 通常都会改变原距离。

若 $\lambda_k = \lambda_{k+1}$, 截断穿过重特征值块, 最优子空间也可能不唯一, 不同部分子空间的结果未必只差一个 k 维旋转。距离扰动很小时, 小谱隙仍可能造成方向变化, 宜比较对齐后的坐标、子空间或重构距离。

同一双中心化计算也适用于核特征距离, 因而可以回到第5.1.7节预告的联系。

定理 5.4 核诱导距离下的等价关系 设 K 为正定核, $K_{i,j} = K(\mathbf{x}_i, \mathbf{x}_j)$, 定义训练点之间的特征距离

$$D_{i,j}^2 = K_{i,i} + K_{j,j} - 2K_{i,j}.$$

对此距离进行经典 MDS, 与对 $\mathbf{K}$ 进行中心化核 PCA, 在选择相同正特征子空间和归一化后给出相同训练坐标。重特征值和截断处的非唯一性与定理5.3相同。

证明. 令向量 $\mathbf{a}$ 的元素 $a_i = K_{i,i}$, 距离平方矩阵为 $\mathbf{a} \mathbf{1}^\top + \mathbf{1} \mathbf{a}^\top - 2\mathbf{K}$ 。双中心化消去前两项, 得到 $\mathbf{B} = \mathbf{H} \mathbf{K} \mathbf{H} = \mathbf{K}_c$ 。式(5.24)与式(5.21)因而输出相同的 $\mathbf{U}_k \boldsymbol{\Lambda}_k^{1/2}$ 。 ■

泛化分析 这里的“泛化”包含统计估计与固定训练表示后的样本外机制。输入是同一批观测产生的欧氏距离且样本独立同分布时，MDS 与 PCA 的等价关系允许沿用前述协方差估计分析。对任意差异矩阵则没有这一直接结论，需要另外说明差异的生成机制及其估计误差。

若新对象到训练对象的距离可计算，经典 MDS 也能给出样本外扩展。设 s_i 为这些距离的平方， $\bar{s} = n^{-1} \sum_i s_i$ ， $r_i = n^{-1} \sum_j D_{i,j}^2$ ， $\bar{r} = n^{-1} \sum_i r_i$ ，则

$$\begin{aligned} b_i &= -\frac{1}{2}(s_i - \bar{s} - r_i + \bar{r}), \\ \mathbf{z}(\mathbf{x}) &= \mathbf{\Lambda}_k^{-1/2} \mathbf{U}_k^\top \mathbf{b}. \end{aligned} \quad (5.28)$$

第一行沿用训练中心化，第二行求内积的最小二乘坐标。这固定了训练点，不等价于加入新点后重做 MDS；非欧氏差异下只是相对于已有表示的近似投影³⁹。

5.2.1.4 小结

MDS 从差异恢复坐标，但经典、度量和非度量形式保留的信息不同。对同一批观测的欧氏距离作经典 MDS，等价于对中心化观测作相同保留维数的 PCA；降到低于中心化数据秩的维数时，两者共享谱截断结果，却都不再精确保留全部原距离。非欧氏性、谱截断与距离矩阵规模是主要限制。

5.2.2 模型对比与总结

已有特征向量且希望保留方差时，PCA 可以直接学习投影；只有对象间差异时，MDS 提供坐标恢复的入口。经典 MDS 比较双中心化后的内积，度量 MDS 比较距离，非度量 MDS 主要匹配差异顺序。选择时应确认原始差异表达哪一种关系，再用相应目标与样本外机制评价，不能把这些形式的目标值直接互比。

5.3 基于邻域的降维

第1.2.2节说明邻域与图可以约束低维坐标。本节具体区分应保留的关系：Isomap 使用图路径近似测地距离，LLE 保留局部重构，拉普拉斯特征映射与扩散映射利用图上的平滑或连通性；SNE、t-SNE 和 UMAP 则优先安排适合观察邻域关系的低维布局。

其中部分方法假设输入接近**流形** (manifold)，即局部能用少量连续坐标描述的空间。弯曲结构的局部方向会随位置改变，直接投影可能混合沿曲面相距很远的点；局部自由度少，也不保证整个空间能在同样维数中无失真地展开。图方法各自需要的采样与几何条件将在相应模型中说明。

沿用章首的 n, d, k, m, q 与矩阵 $\mathbf{X}, \mathbf{Z}$ 。邻域布局中的输入距离记为 $\delta_{i,j} =$

³⁹ Y. Bengio, J.-F. Paiement, P. Vincent, O. Delalleau, N. Le Roux, M. Ouimet, *Out-of-Sample Extensions for LLE, Isomap, MDS, Eigenmaps, and Spectral Clustering* In *Advances in Neural Information Processing Systems*, 2003, pp. 177–184

$\|\mathbf{x}_i - \mathbf{x}_j\|_2$ ，低维距离记为 $r_{i,j} = \|\mathbf{z}_i - \mathbf{z}_j\|_2$ ；布局方法主要学习训练样本的坐标，样本外使用另需规定映射或扩展。

5.3.1 等距映射 (Isomap)

对弯曲流形上的两个点，穿过观测空间的直线距离与沿流形行走的最短距离可能相差很大。后者称为**测地距离** (geodesic distance)，记作 d_M 。**等距映射** (isometric mapping, Isomap) 用邻域图上的最短路径估计这种距离，再调用经典 MDS。Tenenbaum、de Silva 与 Langford 在 2000 年提出该方法；它与同年发表的 LLE 分别选择了路径距离和局部重构关系作为建模对象⁴⁰。

5.3.1.1 模型结构

Isomap 先建立无向邻域图 $\mathcal{G} = (V, E)$ ，顶点对应样本。可以连接距离不超过 ε 的点，也可以将 q 近邻关系对称化；采用并集还是互近邻会改变图，必须明确。每条边的长度取 $\ell_{i,j} = \|\mathbf{x}_i - \mathbf{x}_j\|_2$ 。这里边权是行走成本，越小越近，与后文表示连接强度的相似度权重含义不同。

对图中任意路径，将边长相加，再取最小值，得到

$$d_{\mathcal{G}}(i, j) = \min_{\substack{i=i_0, \dots, i_s=j \\ (i_{a-1}, i_a) \in E}} \sum_{a=1}^s \ell_{i_{a-1}, i_a}. \quad (5.29)$$

形成 $\mathbf{D}_{\mathcal{G}}$ 后，令 $\mathbf{B}_{\mathcal{G}} = -\frac{1}{2} \mathbf{H} \mathbf{D}_{\mathcal{G}}^2 \mathbf{H}$ ，按式(5.24)恢复坐标。这三步分别估计局部连接、汇总全局路径长度、拟合欧氏表示。图距离估计与 MDS 近似是两层不同的误差来源。

图5.6说明邻域选择为何重要。两段曲线虽然在观测空间中接近，沿曲线却可能相距很远；一条跨越弯曲部分的错误边就可能大幅缩短许多点对的最短路径。




图 5.6 一维弯曲曲线上的距离示意。曲线表示嵌入观测空间的一维流形，曲线上的点表示离散样本；沿相邻样本连接的折线表示邻域图路径，其各段长度之和用于近似沿曲线的测地距离。顶部红色虚线是两点间的欧氏直线；若邻域取值过大而把它误纳入图中，就会形成穿过流形外部、低估测地距离的短路。图为几何示意，不是算法输出或实验结果，未给出数值误差。

⁴⁰ J. B. Tenenbaum, V. de Silva, J. C. Langford, *A Global Geometric Framework for Nonlinear Dimensionality Reduction In Science*, 2000, vol. 290, no. 5500, pp. 2319–2323

5.3.1.2 参数学习

暴力计算邻居需约 $O(n^2d)$ 时间；空间索引可能加速低维、分布适宜的数据，但不能保证高维下仍有对数查询成本。对非负边长，从每个点运行带二叉堆的 Dijkstra 算法，成本为 $O(n(|E| + n) \log n)$ ；Floyd-Warshall 算法为 $O(n^3)$ 。随后稠密 MDS 需要 $O(n^2)$ 存储和通常 $O(n^3)$ 的完整谱分解。即使邻域图稀疏，全体点对距离通常仍然稠密。

需要选择的不仅有 q 或 ε ，还有嵌入维数 k 、输入距离及预处理。邻域太小会断连，太大会引入跨越流形的边；噪声和采样密度不均会进一步改变可用尺度。应检查连通分量、边长分布及邻域变化时的嵌入稳定性。距离相关系数给出的残差 $1 - R^2$ 可辅助诊断，但相关性对统一尺度变化不敏感，不能证明距离误差小，更不能证实测地距离估计正确。

标志点 Isomap (Landmark Isomap) 选取 $s \ll n$ 个代表点，只从这些点出发求最短路径，保存 $s \times n$ 的距离表，再由标志点 MDS 和距离扩展得到其他坐标。它不是只算标志点彼此的距离，也不是必须进行三角剖分。de Silva 与 Tenenbaum 的原论文同时讨论了标志点计算和共形变换下的距离修正；两者分别改变计算规模与几何假设，不能混为一种加速技巧⁴¹。

5.3.1.3 理论分析

收敛性分析 Isomap 的最短路径与经典 MDS 步骤各有确定的求解目标；这里更关心采样变密时，所求图距离是否趋近测地距离。为此需要同时避免漏掉必要连接和增加错误捷径，以下确定性结论分别控制这两个误差来源。

主线阅读可把覆盖空隙 h 和单边弦长失真 η 视为两项诊断：前者太大容易断连，后者太大允许短路。进阶证明沿一条最短测地线放置分割点，再用附近样本替代它们，从而构造图路径并控制上下界；它没有证明目标几何一定能嵌入给定的 k 维欧氏空间。

定理 5.5 覆盖条件下的图距离界 设 $\mathcal{M} \subset \mathbb{R}^d$ 连通，任意两点间存在最短测地线。样本的测地填充距离为

$$h = \sup_{\mathbf{x} \in \mathcal{M}} \min_i d_{\mathcal{M}}(\mathbf{x}, \mathbf{x}_i).$$

图连接全部欧氏距离不超过 ε 的样本对，并以欧氏弦长为边长。假设 $h < \varepsilon/2$ ，且存在 $0 \leq \eta < 1$ ，使每条边都满足

$$\|\mathbf{x}_i - \mathbf{x}_j\|_2 \geq (1 - \eta)d_{\mathcal{M}}(\mathbf{x}_i, \mathbf{x}_j).$$

⁴¹ V. de Silva, J. B. Tenenbaum, *Global Versus Local Methods in Nonlinear Dimensionality Reduction* In *Advances in Neural Information Processing Systems*, 2002, pp. 705–712

则对所有样本对，图距离有限，且

$$\begin{aligned} d_g(i, j) &\geq (1 - \eta) d_{\mathcal{M}}(\mathbf{x}_i, \mathbf{x}_j), \\ d_g(i, j) &\leq \left(1 + \frac{2h}{\varepsilon - 2h}\right) d_{\mathcal{M}}(\mathbf{x}_i, \mathbf{x}_j). \end{aligned} \quad (5.30)$$

证明. 对任意图路径，各边弦长至少是对应测地距离的 $1 - \eta$ 倍。将其相加，再用测地距离的三角不等式，就得到下界。

为证明上界，记两端点的测地距离为 L ，取连接它们的一条最短测地线，令 $a = \varepsilon - 2h > 0$ 。若 $L = 0$ ，结论成立；否则沿测地线每隔 a 放一个分割点，末段不足 a ，总段数为 $s = \lceil L/a \rceil$ 。保留原来的两个样本端点，把每个内部分割点替换成测地距离不超过 h 的样本。相邻替代样本的测地距离至多 $a + 2h = \varepsilon$ ，欧氏距离不更大，因此构成图中的边；重复样本可略去。

每个内部分割点的替代误差至多在两条相邻边中各计一次，而两端点无需替代，故所构造路径的长度至多

$$L + 2h(s - 1) \leq L + \frac{2hL}{\varepsilon - 2h}.$$

图最短路径不长于这条路径，得到上界，同时证明图中这些端点相连。■

定理中 h 控制覆盖空隙， η 控制每条边的弦长失真。若一系列样本与邻域满足 $h/\varepsilon \rightarrow 0$ 和 $\eta \rightarrow 0$ ，便得到样本对上统一的相对图距离一致性。仅有曲率有界还不足以排除邻近卷层间的错误边；还需要邻域尺度小于造成跨层连接的尺度。独立采样密度具有正下界时，可以进一步研究 h 随 n 的概率界，但须明确流形体积、维数、覆盖数与密度，不能混写“均匀采样”和任意非均匀密度。

泛化分析 距离一致性不自动保证低维欧氏展开。单位球面赤道上依次相隔四分之一周长的四个点，相邻测地距离为 $\pi/2$ ，两组对点距离为 π 。若这些距离能同时成为欧氏距离，则由三角不等式取等号的条件，另外两点都必须为同一点连线的中点；它们却应相距 π ，产生矛盾。这说明即使测地距离完全已知，也未必存在保持它的欧氏坐标，更不必说二维平面坐标。

Isomap 恢复平直潜在坐标的典型充分情形，是流形与 $\mathbb{R}^m$ 中一个凸区域在长度意义下等距，此时区域内测地距离就是直线距离。带孔的非凸区域即使局部平直，绕孔路径也未必等于直线距离。进入 MDS 步骤后，还需控制距离误差对中心化内积和所选特征子空间的影响。对新点，可用其到邻居的边长加训练图距离估计到全部训练点的距离，再用式(5.28)扩展；这固定了训练图，不等于加入新点后重新求全部最短路径。

5.3.1.4 小结

Isomap 用局部边长构造全局距离，适合检验数据是否具有可展开的长度结构。可靠结果需要足够覆盖、没有短路的邻域，以及目标距离能够被所选欧氏维数近似实现。图断连时跨分量距离为无穷大，必须分别处理或依据额外信息连接，不能随意填入大数并当作原算法的统一嵌入。

5.3.2 局部线性嵌入 (LLE)

如果只信任局部相对位置，而不希望估计全体点对的路径距离，可以把每个样本写成邻居的仿射组合，再把这种组合关系移到低维空间。**局部线性嵌入** (locally linear embedding, LLE) 采用这一思路。它仍依赖距离来选择邻居，也利用局部内积估计权重；绕开的是全局距离矩阵，而不是全部距离信息。

Isomap 与 LLE 的论文在 2000 年同一期《Science》上相邻发表，都尝试由局部可获得的信息组织整个数据集。LLE 尤其强调建立一个统一的全局坐标系，而不只是分别表示若干局部区域；其原文致谢还记录了与 Tenenbaum 的讨论以及对方提供 Isomap 代码的帮助⁴²。两项探索有实际交流，也保留了各自不同的局部约束。

⁴² S. T. Roweis, L. K. Saul, *Nonlinear Dimensionality Reduction by Locally Linear Embedding* In Science, 2000, vol. 290, no. 5500, pp. 2323–2326

5.3.2.1 模型结构

令 $\mathcal{N}_i$ 为样本 i 的 q 个邻居。重构权矩阵 $\mathbf{W} \in \mathbb{R}^{n \times n}$ 满足非邻居权重为零，每行权重和为一，并最小化

$$\min_{\mathbf{W}} \sum_i \left\| \mathbf{x}_i - \sum_j \mathbf{W}_{i,j} \mathbf{x}_j \right\|_2^2, \quad (5.31)$$

满足 $\mathbf{W}\mathbf{1} = \mathbf{1}, \quad \mathbf{W}_{i,j} = 0 \quad (j \notin \mathcal{N}_i).$

行和约束保证平移不变性：对整个邻域加同一个向量，中心点与重构点会同步平移。经典 LLE 不强制权重非负，所以这是仿射组合而不一定是凸组合；权重也不是随机游走概率，矩阵通常不对称。

权重固定后，低维坐标最小化相同形式的重构残差。令 $\mathbf{M} = (\mathbf{I}_n - \mathbf{W})^\top (\mathbf{I}_n - \mathbf{W})$ ，则

$$\min_{\mathbf{Z}} \|\mathbf{Z}(\mathbf{I}_n - \mathbf{W})\|_F^2 = \text{tr}(\mathbf{Z}^\top \mathbf{M} \mathbf{Z}), \quad (5.32)$$

满足 $\mathbf{Z}^\top \mathbf{1} = \mathbf{0}, \quad \mathbf{Z}^\top \mathbf{Z} = n\mathbf{I}_k.$

这些矩阵乘法以样本按行排列为前提。 $\mathbf{Z}\mathbf{M}\mathbf{Z}^\top$ 在此约定下维数不匹配。中心化去掉整体平移，列正交及定范数约束防止所有点塌缩成同一点，但所固定的尺度是代数约定，不是原始距离的尺度。

图5.7中，原邻域中心是三个邻居的加权和，权重依次为 0.3, 0.3, 0.4。移动邻居后，仍用这组权重放置中心点，就能保持该点的零重构残差，而三角形的边长已经改变。完整 LLE 需要同时协调所有邻域，再满足全局约束；单个三角形只展示其中一项局部关系。




图 5.7 LLE 局部权重保持的示意。左图用二维局部坐标绘出三个邻居和菱形中心点；虚线旁为重构权重，其和为 1。右图将邻居移至所标位置，同样的权重给出中心 $(0.60, 0.55)^T$ 。两图使用相同的无量纲尺度，实线三角形的形状与边长可以改变。两个画面用于对照高维局部几何与目标邻域，不是完整 LLE 输出，也不表示一次二维到二维的降维。

5.3.2.2 参数学习

将第 i 个邻域按固定顺序排列，令 $A_i \in \mathbb{R}^{q \times d}$ 的每行为 $(x_j - x_i)^T$ ，局部 Gram 矩阵为 $C_i = A_i A_i^T$ 。局部权重 $w_i \in \mathbb{R}^q$ 的目标变为

$$\min_{\mathbf{1}^T w_i = 1} w_i^T C_i w_i.$$

若 C_i 正定，拉格朗日驻点条件给出 $C_i w_i = c \mathbf{1}$ ，再用行和约束确定 c ，得到

$$w_i = \frac{C_i^{-1} \mathbf{1}}{\mathbf{1}^T C_i^{-1} \mathbf{1}}. \quad (5.33)$$

实现时求解线性方程即可，不必显式求逆。 $q > d$ 时矩阵必奇异；即使 $q \leq d$ ，流形局部接近 m 维切空间，也可能使它秩亏或病态。常用正则化 $C_i + \rho_i I_q$ ，例如令 ρ_i 与 $\text{tr}(C_i)$ 成比例；若邻居全部重合、迹为零，还需要正的尺度下限或单独处理。正则化改善条件数，也改变了原来的重构问题。

由 $W\mathbf{1} = \mathbf{1}$ 可知 $M\mathbf{1} = \mathbf{0}$ 。设常数方向之外最小的 k 个特征方向组成 U_k ，且其列为单位向量，则式(5.32)的解是 $Z = \sqrt{n} U_k$ 。只有在零空间恰好由常数向量张成时，才可以简单地“取最小 $k+1$ 个特征向量，再丢掉一个”。图有多个断连分量时，各分量的指示向量都是零模态；连通也并

不对任意带符号权重保证零空间只有一维。

这种退化有明确后果：在只排除全局常数方向后，剩余零能量坐标可能只是在给不同分量分配常数，而没有表达分量内部形状。即使各分量能分别求嵌入，整体相对位置、方向和尺度也不由局部重构关系确定，不能据此声称 LLE 对断连问题更稳健。

局部 Gram 矩阵构造与线性求解约需 $O(nq^2d + nq^3)$ 。全局阶段不必显式形成可能更稠密的 $\mathbf{M}$ ，可以先乘 $\mathbf{I}_n - \mathbf{W}$ ，再乘其转置，一次矩阵向量乘约需 $O(nq)$ 。部分特征求解的总成本还依赖谱隙、迭代次数与重正交，不能统一写成 $O(n^2)$ 。实际超参数至少包括 q 、 k 和正则化尺度。

LLE 的几何依据是局部近似，而非任意等距变换都严格保持重构权。对一个光滑坐标函数 f ，在局部坐标中令邻居位移为 ξ_j ，Taylor 展开给出

$$f(\mathbf{x}_i) - \sum_j \mathbf{w}_{i,j} f(\mathbf{x}_j) = -\nabla f^\top \sum_j \mathbf{w}_{i,j} \xi_j + O\left(\sum_j \|\mathbf{w}_{i,j}\| \|\xi_j\|_2^2\right).$$

权重和为一消去了常数项；若加权位移接近零，一阶项也小，重构误差主要受曲率和二阶变化影响。大幅正负抵消的权重会放大余项，噪声也会改变邻域与局部 Gram 矩阵，所以局部建模本身不提供无条件抗噪保证。

固定训练嵌入后，新点可按同样的局部约束求权重，再令 $\mathbf{z}(\mathbf{x}) = \sum_{j \in \mathcal{N}(\mathbf{x})} \mathbf{w}_j(\mathbf{x}) \mathbf{z}_j$ 。这是局部插值，不是重新求全局特征向量；训练支持之外或邻域选择不稳定的点仍可能得到失真坐标。

5.3.2.3 小结

LLE 保留的是局部仿射重构关系，不是距离或角度的精确保真。它免去全体点对最短路径计算，却依然受邻域尺度、局部秩、权重稳定性与全局零空间影响。Hessian LLE 进一步约束局部二阶变化，局部切空间对齐 (LTSA) 则显式估计并对齐切空间；这些扩展将在本节比较中说明各自增加的条件，而不是视为对任意流形都成立的展开保证。

5.3.3 拉普拉斯特征映射 (Laplacian Eigenmaps)

除了拟合局部重构关系，还可以直接要求邻近点的坐标变化缓慢。**拉普拉斯特征映射** (Laplacian Eigenmaps) 把这种平滑要求写成图上的二次能量，再在防止塌缩的约束下寻找低能量坐标。Belkin 与 Niyogi 在 NIPS 2001 介绍了相关谱方法，2003 年的期刊论文系统展开了模型及其几何联系。它与第4.3.1节的谱聚类共享建图、图拉普拉斯和低频特征向量，但这里输出连续坐标，谱聚类还要把谱表示离散为簇分配⁴³。

⁴³ M. Belkin, P. Niyogi, *Laplacian Eigenmaps for Dimensionality Reduction and Data Representation* In *Neural Computation*, 2003, vol. 15, no. 6, pp. 1373–1396

5.3.3.1 模型结构

在对称化邻域图上定义非负相似度 $\mathbf{W}_{i,j}$, 相邻点可取 $\exp(-\|\mathbf{x}_i - \mathbf{x}_j\|_2^2 / (4\tau))$ 或 1, 其余位置取零。 $\tau > 0$ 控制权重衰减尺度。令 $b_i = \sum_j \mathbf{W}_{i,j}$, 度矩阵 $\mathbf{D}_b = \text{diag}(b_1, \dots, b_n)$, 图拉普拉斯矩阵 $\mathbf{L} = \mathbf{D}_b - \mathbf{W}$ 。对任意标量图信号 $\mathbf{f} \in \mathbb{R}^n$, 对称性给出

$$\mathbf{f}^\top \mathbf{L} \mathbf{f} = \frac{1}{2} \sum_{i,j} \mathbf{W}_{i,j} (f_i - f_j)^2. \quad (5.34)$$

因此 $\mathbf{L}$ 半正定, 常数信号的能量为零。把各坐标的能量相加, 模型变为

$$\begin{aligned} \min_{\mathbf{Z}} \quad & \text{tr}(\mathbf{Z}^\top \mathbf{L} \mathbf{Z}), \\ \text{满足} \quad & \mathbf{Z}^\top \mathbf{D}_b \mathbf{Z} = \mathbf{I}_k, \quad \mathbf{Z}^\top \mathbf{D}_b \mathbf{1} = \mathbf{0}. \end{aligned} \quad (5.35)$$

度加权定范数防止零解, 加权中心化排除常数方向。只写第一个约束而不排除常数, 会把一个没有区分能力的方向纳入嵌入。该目标鼓励相邻点靠近, 却没有逐对强制远点分离, 不能单凭低能量就断言全局距离保真。

5.3.3.2 参数学习

对一个坐标列求拉格朗日驻点, 在常数正交子空间中得到 $\mathbf{L}\mathbf{v} = \lambda \mathbf{D}_b \mathbf{v}$ 。若各点度为正, 令 $\mathbf{u} = \mathbf{D}_b^{1/2} \mathbf{v}$, 可化为普通对称特征值问题:

$$\mathbf{L}_{\text{sym}} \mathbf{u} = \lambda \mathbf{u}, \quad \mathbf{L}_{\text{sym}} = \mathbf{I}_n - \mathbf{D}_b^{-1/2} \mathbf{W} \mathbf{D}_b^{-1/2}.$$

求得单位向量 $\mathbf{u}$ 后, 应变回 $\mathbf{v} = \mathbf{D}_b^{-1/2} \mathbf{u}$, 才能满足式(5.35)的归一化。对连通图, 广义问题的零特征向量为常数, 对称问题的零特征向量却与 $\mathbf{D}_b^{1/2} \mathbf{1}$ 成比例。图有多个连通分量时, 应识别全部零模态; 零度点则不能直接参与逆度归一化。

若 $\mathbf{W}$ 有 $O(nq)$ 个非零元, 矩阵向量乘也为 $O(nq)$, 适合使用部分谱求解器。总成本仍包含邻域构造、所求维数 k 、迭代和正交化, 并无统一的 $O(nq^2)$ 保证。 q 决定连接关系, τ 决定已连接点之间的相对权重, k 决定保留多少坐标。带宽过小会使部分度数接近零, 过大会弱化局部差异, 二者都应通过图诊断与任务评价检查。

5.3.3.3 理论分析

收敛性分析 这里区分固定图上的特征值求解与采样变密时的谱收敛。前者逼近一个有限维代数问题, 后者需要把离散能量与连续对象联系起来。式(5.34)的连续对应物是 **Dirichlet 能量**, 即函数沿流形各方向的变化率平方

的积分。采用非负号约定 $\Delta_{\mathcal{M}} = -\operatorname{div}_{\mathcal{M}} \nabla_{\mathcal{M}}$ ，在紧致无边界流形上，

$$\mathcal{E}(f) = \int_{\mathcal{M}} \|\nabla_{\mathcal{M}} f\|_2^2 dV = \int_{\mathcal{M}} f \Delta_{\mathcal{M}} f dV. \quad (5.36)$$

这个 Laplace–Beltrami 算子衡量函数相对局部邻域的变化，类似欧氏空间中的负拉普拉斯。为求均值为零、平方积分为一的最平滑函数，对能量加上约束乘子，并沿任意光滑扰动 g 求导：

$$2 \int_{\mathcal{M}} g \Delta_{\mathcal{M}} f dV - 2\lambda \int_{\mathcal{M}} g f dV - 2c \int_{\mathcal{M}} g dV = 0.$$

分部积分给出第一项；取 $g = 1$ 得 $c = 0$ ，再利用 g 任意，得到 $\Delta_{\mathcal{M}} f = \lambda f$ 。依次增加与已选特征函数正交的约束，就得到从低频到高频的方向。这说明低频坐标为何平滑，而不是仅凭“流形像一张图”的类比来解释算法。

从图到流形有两个不同问题。点态算子收敛考察固定光滑函数 f 经离散算子作用后是否接近 $\Delta_{\mathcal{M}} f$ ；谱收敛则考察随样本变化的特征值与特征函数，不能由前者直接推出。Belkin 与 Niyogi 在 2006 年发表的谱收敛研究，专门连接了经验算子的谱逼近与小带宽下的连续谱逼近⁴⁴。

定理 5.6 一种定性的谱一致性结论 设 $\mathcal{M}$ 是紧致、连通、无边界的 C^∞ 嵌入 m 维黎曼流形，为简化常数令其体积为一。样本独立均匀采自 $\mathcal{M}$ 。考虑全连接高斯图对应的经验算子

$$\begin{aligned} \hat{\mathcal{L}}_{n,\tau} f(\mathbf{x}) &= \frac{1}{n\tau(4\pi\tau)^{m/2}} \\ &\cdot \sum_{j=1}^n e^{-\|\mathbf{x}-\mathbf{x}_j\|_2^2/(4\tau)} (f(\mathbf{x}) - f(\mathbf{x}_j)). \end{aligned}$$

存在趋于零而足够缓慢的带宽序列 τ_n ，使每个固定的低频特征值依概率收敛到 $\Delta_{\mathcal{M}}$ 的相应特征值。将经验特征向量按该算子延拓并作 $L^2(\mathcal{M})$ 归一化后，孤立单特征值对应的特征函数可在符号对齐后依概率收敛；重特征值应按相应有限维特征子空间比较。

定理陈述的是一种具体高斯算子和存在性的带宽选择，不是任意 q 近邻图、任意带宽序列的保证。归一化幂次取决于内在维数 m ，而非观测维数 d 。定理中的未归一化算子与式(5.35)的度归一化广义问题也需区分：均匀采样时度的极限趋向空间常数，经过尺度校正可联系二者；非均匀采样、稀疏截断或有边界时，须重新分析度、极限测度及边界条件。

泛化分析 在非均匀密度 p 下，未经密度修正的局部能量一般会包含 p^2 权重，密集区域对低频表示的影响更大。即便已证明谱收敛，截取少数特征函数也不保证映射单射或保持所有距离。样本外表示可通过核特征函数

⁴⁴ M. Belkin, P. Niyogi, *Convergence of Laplacian Eigenmaps* In *Advances in Neural Information Processing Systems*, 2006, pp. 129–136

延拓或另拟合映射获得；第3.6.2节的标签传播在已知类别语义下求类别得分，第4.3.1节的谱聚类输出簇分配，本节则直接输出连续低维坐标。三者复用图平滑方向，却需要不同的目标和评价依据。

5.3.3.4 小结

拉普拉斯特征映射把邻域相似度转成平滑坐标，其解释来自离散二次能量与连续 Dirichlet 能量的对应。正确使用它需要区分对称与广义特征向量、常数零模态与断连零空间，以及点态和谱两种收敛。它提供的是所建图上的低频表示，并不自动消除采样密度，也不自动保持全局距离。

5.3.4 扩散映射 (Diffusion Map)

平滑坐标还留下一个问题：嵌入中两点的欧氏距离，在原图上究竟表示什么？**扩散映射** (diffusion map) 从随机游走回答它：若从两个点出发，经过相同步数后到达各处的概率相似，就把这两个点视为接近。Coifman 与 Lafon 在 2006 年的论文将这一概率距离写成谱坐标，并用时间参数控制保留的扩散尺度⁴⁵。

⁴⁵ R. R. Coifman, S. Lafon, *Diffusion Maps In Applied and Computational Harmonic Analysis*, 2006, vol. 21, no. 1, pp. 5–30

5.3.4.1 模型结构

令 $\mathbf{K}$ 为对称、非负的原始相似度矩阵，例如全连接高斯核或稀疏邻域权重。为区分邻居数 q 与度数，记原始度为 r_i ，密度重加权后的度为 b_i ：

$$\begin{aligned} r_i &= \sum_j \mathbf{K}_{i,j}, \quad \tilde{\mathbf{K}}_{i,j} = \frac{\mathbf{K}_{i,j}}{r_i^\alpha r_j^\alpha}, \\ b_i &= \sum_j \tilde{\mathbf{K}}_{i,j}, \quad \mathbf{P}_{i,j} = \frac{\tilde{\mathbf{K}}_{i,j}}{b_i}, \quad 0 \leq \alpha \leq 1. \end{aligned} \quad (5.37)$$

假设所用度数均为正。 $\mathbf{P}$ 每行和为一，是转移概率矩阵； $\mathbf{P}_{i,j}$ 表示从 i 一步走到 j 的概率。其平稳分布由重加权后的度决定：

$$\pi_i = \frac{b_i}{\sum_j b_j}, \quad \pi_i \mathbf{P}_{i,j} = \pi_j \mathbf{P}_{j,i}. \quad (5.38)$$

末式称为详细平衡，表示平稳状态下每对点的双向概率流相等；由此求和可验证 $\boldsymbol{\pi}^\top \mathbf{P} = \boldsymbol{\pi}^\top$ 。除 $\alpha = 0$ 等特殊情形，不能用原始 r_i 替代 b_i 计算平稳分布。

对整数 $t \geq 0$ ，令 $p_t(i, j) = (\mathbf{P}^t)_{i,j}$ 。扩散距离定义为

$$D_t^2(i, j) = \sum_{a=1}^n \frac{(p_t(i, a) - p_t(j, a))^2}{\pi_a}. \quad (5.39)$$

它比较两整个转移分布，而非某条路径的长度。分母用平稳概率校正目标

点的权重：相同的概率差异，在很少被访问的点上计入更大的贡献。若两个起点的转移分布恰好相同， D_t 也可能为零，因此在一般图上严格说可为伪度量。瓶颈会减缓两侧分布混合，使某些扩散尺度能够分辨这些区域。

图5.8用两个只由一条弱边连接的团展示这种现象。团内传播很快，跨团却必须经过弱桥；4步后，大部分概率仍留在出发一侧。到64步时，两行分布已经接近一些，但并未相同。扩散距离比较的正是这些到达概率的差异，并按 π_a 加权；图中节点之间画得多远并不进入该距离。




图 5.8 扩散时间与跨团瓶颈。每团三个节点，团内边及所有自环权重为 1，唯一跨团边权重为 0.15。令 $\alpha = 0$ 并按行归一化，热图两行分别表示从左 1、右 3 出发的 P^t 对应行，六列为固定节点顺序；各时刻共用同一连续概率色标。数值由有理数矩阵乘法计算，显示三位小数，舍入后行和可能略偏离 1。64 步仍未充分混合；因图连通且有自环，极限分布均为 $\pi^T = (20, 20, 21, 21, 20, 20)/122$ 。

5.3.4.2 参数学习

记 $\Pi = \text{diag}(\pi_1, \dots, \pi_n)$ 。详细平衡保证

$$S = \Pi^{1/2} P \Pi^{-1/2}$$

对称。取 S 的欧氏单位特征向量 $\mathbf{u}_\ell$ ，令 $\psi_\ell = \Pi^{-1/2} \mathbf{u}_\ell$ ，则

$$\begin{aligned} P\psi_\ell &= \lambda_\ell \psi_\ell, \\ \sum_i \pi_i \psi_\ell(i) \psi_r(i) &= \delta_{\ell,r}. \end{aligned} \quad (5.40)$$

这是在 $L^2(\pi)$ 内积下正交，不是普通欧氏正交。若图连通，平凡特征对为 $\lambda_0 = 1, \psi_0(i) = 1$ 。其余特征值为实数且位于 $[-1, 1]$ ；假设链还非周期，则绝对值严格小于一。保留正自环的连通图满足非周期性，无自环二部图则可能有 -1 特征值。

一般对称非负权重不保证正半定，因而可能产生负特征值；此时应按 $|\lambda_1| \geq |\lambda_2| \geq \dots$ 选择主要扩散模态。全连接正定核经上述对角缩放仍保持半正定，才可按非负特征值降序处理；稀疏截断可能破坏这一性质。定义 k 维扩散坐标

$$\Psi_{t,k}(i) = (\lambda_1^t \psi_1(i), \dots, \lambda_k^t \psi_k(i))^\top. \quad (5.41)$$

第 i 行取其转置便得到 $n \times k$ 嵌入矩阵。指数 t 是矩阵乘方所对应的步数；含负谱时不能随意用实数 t 解释 λ_ℓ^t 。

稠密构造、存储和完整谱分解的成本与核 PCA 同阶。稀疏权重允许低成本矩阵向量乘，但总求谱成本仍由 k 、谱间隔、迭代精度决定。除邻域或核带宽、 k 外，还应选择 α 与 t 。时间加权使模态重要性发生变化，而不需要每个 t 都重新求一次谱。

5.3.4.3 理论分析

收敛性分析 扩散距离的谱表达是有限图上就成立的代数恒等式，不依赖流形采样的渐近极限。先证明它，再讨论截断和连续几何，才能分清不同层次的保证。

主线阅读只需使用两个结果：完整非平凡谱精确表示扩散距离，截断误差受未保留特征值和平稳概率共同控制。进阶证明在 $L^2(\pi)$ 内积下展开转移概率，并用正交性消去交叉项；它不能替代核尺度和有限样本图结构的敏感性检查。

定理 5.7 扩散距离的谱表示与截断界 设 P 由连通的对称非负权重构造， $\pi_i > 0$ ，特征函数按式(5.40)归一化。对整数 $t \geq 0$ ，全部非平

凡模态给出

$$D_t^2(i, j) = \sum_{\ell=1}^{n-1} \lambda_{\ell}^{2t} (\psi_{\ell}(i) - \psi_{\ell}(j))^2. \quad (5.42)$$

当 $t = 0$ 时按 $\mathbf{P}^0 = \mathbf{I}_n$ 约定所有模态系数为一。若按特征值绝对值排序, $k < n - 1$ 且 $i \neq j$, 截断的平方距离误差 $R_{t,k}$ 满足

$$\begin{aligned} R_{t,k}(i, j) &:= D_t^2(i, j) - \|\Psi_{t,k}(i) - \Psi_{t,k}(j)\|_2^2, \\ 0 \leq R_{t,k}(i, j) &\leq |\lambda_{k+1}|^{2t} \left(\frac{1}{\pi_i} + \frac{1}{\pi_j} \right). \end{aligned} \quad (5.43)$$

证明. 对称矩阵 $\mathbf{S}$ 的谱分解给出

$$p_t(i, a) = \pi_a \sum_{\ell=0}^{n-1} \lambda_{\ell}^t \psi_{\ell}(i) \psi_{\ell}(a).$$

令 $c_{\ell} = \lambda_{\ell}^t (\psi_{\ell}(i) - \psi_{\ell}(j))$, 则 $c_0 = 0$ 。代入定义, 展开平方并使用加权正交性:

$$\begin{aligned} D_t^2(i, j) &= \sum_a \pi_a \left(\sum_{\ell=1}^{n-1} c_{\ell} \psi_{\ell}(a) \right)^2 \\ &= \sum_{\ell, r=1}^{n-1} c_{\ell} c_r \sum_a \pi_a \psi_{\ell}(a) \psi_r(a) = \sum_{\ell=1}^{n-1} c_{\ell}^2. \end{aligned}$$

其中 π_a 来自分子中 π_a^2 除以定义中的 π_a , 不能再次消去。截断后余项是 $\ell > k$ 的非负和。由绝对值排序及完整正交基关系,

$$\begin{aligned} R_{t,k} &\leq |\lambda_{k+1}|^{2t} \sum_{\ell=1}^{n-1} (\psi_{\ell}(i) - \psi_{\ell}(j))^2, \\ \sum_{\ell=0}^{n-1} \psi_{\ell}(i) \psi_{\ell}(j) &= \frac{\delta_{i,j}}{\sqrt{\pi_i \pi_j}}, \end{aligned}$$

对 $i \neq j$ 展开平方, 即得所述上界; $i = j$ 时两种距离和余项都为零。 ■

全部 $n - 1$ 个模态实现精确距离, 截取 k 维一般只能近似。误差不只取决于 $|\lambda_{k+1}|^{2t}$, 还取决于特征函数在点上的幅度; 式(5.43)中的平稳概率因子说明, 稀少区域可能有较大的绝对误差界。误差随时间变小也不保证相对精度, 因为被近似的距离本身同时变小。

对不可约、非周期的有限链, 所有非平凡模态都满足 $|\lambda_{\ell}| < 1$, 故 $t \rightarrow \infty$ 时 $p_t(i, \cdot) \rightarrow \pi^{\top}$, 所有 $D_t(i, j) \rightarrow 0$ 。较大但未充分混合的 t 突出慢模态; 无限增大 t 会丢失区分, 而不是越来越完整地恢复全局结构。若需要连续时间, 可使用 $\exp[-s(\mathbf{I}_n - \mathbf{P})]$, 其权重为 $e^{-s(1-\lambda_{\ell})}$, 而不能把离散步数直接当作任意实数。

在相同对称权重下，拉普拉斯广义问题满足

$$(\mathbf{D}_b - \mathbf{W})\mathbf{v} = \mu \mathbf{D}_b \mathbf{v} \iff \mathbf{P}\mathbf{v} = (1 - \mu)\mathbf{v}.$$

所以二者共享对应特征方向。把有限个选定方向的时间权重设为一，并统一归一化，才得到无时间加权的拉普拉斯坐标； $L^2(\pi)$ 与 $\mathbf{D}_b$ 归一化还相差一个全局尺度。存在负谱并按绝对值选模态时，扩散映射甚至可能优先保留拉普拉斯的高端模态。因而不能不加条件地把二者等同于 $t \rightarrow 0$ 的极限。

泛化分析 密度修正的含义属于另一层渐近分析。在光滑正密度 p 、足够采样和小高斯带宽的内点极限中，重加权随机游走的生成元含有与 $2(1 - \alpha)\nabla_{\mathcal{M}} \log p$ 有关的漂移。取 $\alpha = 1$ 消去这一主导密度漂移，得到由流形几何决定的扩散算子；它不是有限样本下精确消除密度影响。取 $\alpha = 0$ 则保留密度对随机游走的影响，有时这正是任务所关心的概率结构。

扩散映射也有样本外 Nyström 延拓。沿用训练核与 r_j ，对新点计算 $r(\mathbf{x}) = \sum_j \kappa(\mathbf{x}, \mathbf{x}_j)$ ，再按式(5.37)构造到训练点的归一化转移概率 $p(\mathbf{x}, j)$ 。对 $\lambda_\ell \neq 0$,

$$\psi_\ell(\mathbf{x}) = \frac{1}{\lambda_\ell} \sum_j p(\mathbf{x}, j) \psi_\ell(j), \quad z_\ell(\mathbf{x}) = \lambda_\ell^t \psi_\ell(\mathbf{x}). \quad (5.44)$$

它把训练特征方程延伸到新点，保持训练度和谱不变；很小的特征值会放大误差，零特征值不能这样求逆。对图结构的错误连接，扩散概率可能分散单条边的影响，也可能因其显著改变瓶颈而严重失真，不能由“使用多条路径”推出普遍优于 Isomap。

5.3.4.4 小结

扩散映射为谱坐标赋予了明确的概率距离解释：以重加权后的平稳分布定义距离，在 $L^2(\pi)$ 中归一化特征函数，再用时间因子控制各模态。各向异性的 α 重加权调整密度作用，扩散小波以扩散算子的幂组织多尺度函数基；后者不只是选择几个不同 t 画散点图⁴⁶。

向量扩散映射进一步把邻域之间的方向对齐纳入传播，适合研究切向量和局部方向的一致性。它与标量扩散共享多步传播思路，却需要额外估计局部坐标系。核尺度、采样误差、慢模态选择、混合时间及延拓稳定性仍是这些表示的实际限制。

5.3.5 随机邻居嵌入 (SNE)

同样一段距离，在稠密区域可能跨过许多样本，在稀疏区域却只够到达最近邻。Hinton 与 Roweis 于 2002 年提出的**随机邻居嵌入** (stochastic neighbor

⁴⁶ R. R. Coifman, M. Maggioni, *Diffusion Wavelets In Applied and Computational Harmonic Analysis*, 2006, vol. 21, no. 1, pp. 53–94

embedding, SNE) 为每个样本建立“选择谁作邻居”的概率分布, 让低维表示复现这种选择倾向。“随机”描述概率模型, 不意味着坐标是随机抽取的。

原论文还以单词 bank 为例讨论歧义: 它既与河岸有关, 也与金融语境有关, 只给一个低维位置可能难以同时表达这两组关系。作者因而讨论了允许同一对象具有多个位置的混合扩展⁴⁷。本节先介绍每个样本只有一个位置的基本形式; 这个历史例子说明, 如何定义邻域之外, 还存在低维表示本身是否足以表达语义的问题。

⁴⁷ G. E. Hinton, S. Roweis, *Stochastic Neighbor Embedding* In *Advances in Neural Information Processing Systems*, 2002, pp. 857–864

5.3.5.1 模型结构

以样本 i 为中心, SNE 用高斯核比较其他样本的相对接近程度, 定义

$$p_{j|i} = \frac{\exp(-\delta_{i,j}^2 / (2\sigma_i^2))}{\sum_{\ell \neq i} \exp(-\delta_{i,\ell}^2 / (2\sigma_i^2))}, \quad j \neq i, \quad (5.45)$$

$$p_{i|i} = 0, \quad \sum_{j \neq i} p_{j|i} = 1.$$

带宽 $\sigma_i > 0$ 控制局部尺度: 带宽小时, 概率集中在少数近邻上; 带宽大时, 较远样本也获得较多权重。尽管距离对称, $p_{j|i}$ 和 $p_{i|j}$ 一般不等, 因为带宽和归一化分母不同。

给定 $P_i = (p_{j|i})_{j \neq i}$, 用**困惑度** (perplexity) 衡量它相当于在多少个邻居之间作均匀选择, 再据此确定带宽。采用自然对数时,

$$H(P_i) = - \sum_{j \neq i} p_{j|i} \log p_{j|i}, \quad (5.46)$$

$$\text{Perp}(P_i) = \exp(H(P_i)).$$

若 q 个邻居均分概率, 其余为零, 困惑度就是 q ; 一般情况下它可以是非整数, 并非硬截断的近邻数。若熵使用以 2 为底的对数, 外层才写成 $2^{H_2(P_i)}$ 。

给定目标困惑度 τ , 可以二分搜索带宽。令 $\beta_i = 1/(2\sigma_i^2)$ 、 $D_j = \delta_{i,j}^2$ 、 $B_i = \sum_{j \neq i} \exp(-\beta_i D_j)$, 则

$$H(P_i) = \log B_i + \beta_i \mathbb{E}_{P_i}[D],$$

$$\frac{d}{d\beta_i} \mathbb{E}_{P_i}[D] = -\text{Var}_{P_i}(D), \quad (5.47)$$

$$\frac{dH(P_i)}{d\beta_i} = -\beta_i \text{Var}_{P_i}(D) \leq 0.$$

困惑度随 σ_i 单调不减, 候选距离不全相等时严格递增。若有 h_i 个并列最近邻, 带宽趋于零和无穷时, 困惑度分别趋于 h_i 和 $n-1$ 。因此, 仅当 $\tau \in (h_i, n-1)$ 时存在唯一有限正带宽; 距离全相等时, 困惑度恒为 $n-1$ 。

重复样本和距离并列都可能限制可达目标。

稀疏区域通常需要较大带宽，稠密区域需要较小带宽，但自适应尺度并不保留原始密度。困惑度常从 5 至 50 尝试，还需结合样本数和群体规模；标准化、去噪和特征选择也会改变邻居分布，带宽搜索不能自动消除无关特征。

在低维空间，SNE 固定核尺度，仅让坐标变化：

$$q_{j|i} = \frac{\exp(-r_{i,j}^2)}{\sum_{\ell \neq i} \exp(-r_{i,\ell}^2)}, \quad q_{i|i} = 0, \\ C_{\text{SNE}}(\mathbf{Z}) = \sum_i \text{KL}(P_i \| Q_i) \quad (5.48) \\ = \sum_i \sum_{j \neq i} p_{j|i} \log \frac{p_{j|i}}{q_{j|i}}.$$

其中 $Q_i = (q_{j|i})_{j \neq i}$ 。 $\exp(-r^2)$ 对应方差为 $1/2$ 、标准差为 $1/\sqrt{2}$ 的高斯核。固定带宽是在选择坐标单位；改变共同带宽可由坐标缩放吸收，但带宽固定后单独缩放坐标仍会改变目标。

KL 散度优先匹配较大的 $p_{j|i}$ ：把这些近邻拉远会增大 $-\log q_{j|i}$ 。但单项 $p_{j|i} \log(p_{j|i}/q_{j|i})$ 可能为负，非负的是整体散度。高维远点挤到低维近处也会占用 Q_i 的概率质量，减少真正近邻分得的概率；归一化竞争因此会产生斥力。

5.3.5.2 参数学习

SNE 先根据 $\mathbf{X}$ 和 τ 求带宽，固定 P_i 后再优化 $\mathbf{Z}$ 。令 $A_i = \sum_{\ell \neq i} \exp(-r_{i,\ell}^2)$ ，第 i 个散度可写为

$$C_i = \sum_{j \neq i} p_{j|i} \log p_{j|i} + \sum_{j \neq i} p_{j|i} r_{i,j}^2 + \log A_i. \quad (5.49)$$

第一项与坐标无关，第二项缩短高概率邻居的距离，第三项来自归一化。只对距离项求导，会丢失防止点云塌缩的作用。

坐标 $\mathbf{z}_i$ 以两种身份影响总损失。它是 C_i 的中心点，也是每个 C_j 中的候选邻居。因此分别有

$$\nabla_{\mathbf{z}_i} C_i = 2 \sum_{j \neq i} (p_{j|i} - q_{j|i})(\mathbf{z}_i - \mathbf{z}_j), \quad (5.50) \\ \nabla_{\mathbf{z}_i} C_j = 2(p_{i|j} - q_{i|j})(\mathbf{z}_i - \mathbf{z}_j), \quad j \neq i.$$

第一行中的负项来自 $\nabla_{\mathbf{z}_i} \log A_i$ ；对 $\log A_j$ 求导时，只有包含 i 的核项变化，

得到第二行中的负项。相加得到

$$\begin{aligned} \nabla_{\mathbf{z}_i} C_{\text{SNE}} = 2 \sum_{j \neq i} [(p_{j|i} - q_{j|i}) \\ + (p_{i|j} - q_{i|j})](\mathbf{z}_i - \mathbf{z}_j). \end{aligned} \quad (5.51)$$

方括号内系数为正时，梯度指向远离 j 的方向，负梯度更新才把 i 拉向 j ；系数为负时则推开。吸引力和斥力描述的是负梯度，且两个有向残差可能相互抵消，不能只看一个方向。

基本更新为 $\mathbf{Z}^{(t+1)} = \mathbf{Z}^{(t)} - \eta_t \nabla C_{\text{SNE}}(\mathbf{Z}^{(t)})$ ，学习率 $\eta_t > 0$ 。可加入动量，带入上一轮的部分位移。原始工作还使用逐渐减弱的随机扰动帮助离开不良布局，但没有全局最优保证。初始化可取小随机点云，避免全部重合造成对称的零梯度状态。

完整高维距离计算需 $O(n^2 d)$ 时间、概率矩阵需 $O(n^2)$ 存储；固定 k 时，每轮嵌入优化为 $O(n^2)$ 。迭代需监测目标值、梯度或位移和近邻保留情况；数值停止变化不等于图上结构都可靠。

5.3.5.3 理论分析

收敛性分析 C_{SNE} 对坐标非凸；平移、旋转和反射又使坐标不唯一。梯度光滑、步长合适时，可讨论下降或趋近驻点，但没有任意初始化下的全局收敛保证。谱方法虽通常能全局求解固定图上的特征值子问题，也不意味着选错近邻图后仍能恢复真实几何。数值求解与结构保真需要分开。

更充分的迭代也不能消除**拥挤问题** (crowding problem)，即许多高维邻域关系难以同时放进低维空间。若样本局部近似均匀地分布在 m 维流形上，在足够小且远离边界的尺度内，半径 r 内的样本数近似随 r^m 增长，而 k 维体积随 r^k 增长。这里使用内在维数 m 而非观测维数 d ；体积比较只是容量冲突的直觉，不是任意数据的计数定理。

当 $m > k$ 时，大量中距离邻居难以同时得到合适位置，高斯核的快速衰减又限制了布局。图5.9中， $r = 3$ 时高斯核约为 0.00012，Cauchy 形核为 0.1，后者允许较远点仍保有相似度。这只是核值比较，实际概率还依赖归一化。

泛化分析 标准 SNE 只输出训练坐标，没有直接接收新样本的函数。样本外扩展需另行规定邻域关系及旧坐标是否固定；训练邻域保留良好不代表新点表示稳定。若输入距离由噪声支配，充分优化也可能只是忠实展示噪声。




图 5.9 高斯核 $\exp(-r^2)$ 与 Cauchy 形核 $1/(1+r^2)$ 的尾部。横轴 r 为无量纲距离，纵轴为未归一化核值，非概率密度、非实验结果；尾部形状本身不保证嵌入保真。

5.3.5.4 小结

SNE 以困惑度确定尺度，以条件概率表达邻近，以 KL 散度匹配分布。它留下三个不同问题：低维模型能否表达输入邻域，优化能否找到合适布局，点对计算能否承受。更换核、改进优化和加速计算分别处理这些问题，不能彼此替代。

5.3.6 t-SNE

为缓解拥挤，可让低维相似度随距离衰减得慢一些。van der Maaten 与 Hinton 于 2008 年提出的 **t-SNE** (t-distributed stochastic neighbor embedding) 采用重尾低维核，同时把逐点条件分布改成对称点对分布；它不只是替换 SNE 的指数函数⁴⁸。

5.3.6.1 模型结构

高维条件概率仍由式(5.45)和困惑度确定。为使同一对样本具有一个共同权重，t-SNE 定义

$$\begin{aligned} p_{i,j} &= \frac{p_{j|i} + p_{i|j}}{2n}, & i \neq j, \\ p_{i,i} &= 0, & p_{i,j} = p_{j,i}, & \sum_{i \neq j} p_{i,j} = 1. \end{aligned} \quad (5.52)$$

求和遍历有序对， (i, j) 和 (j, i) 各出现一次。 n 个条件分布每行和为 1，对称化后总和为 $2n$ ，故分母取 $2n$ 。改用无序对 $i < j$ 时，归一化和系数也要相应调整。

⁴⁸ L. van der Maaten, G. Hinton, *Visualizing Data using t-SNE* In *Journal of Machine Learning Research*, 2008, vol. 9, no. 86, pp. 2579–2605

低维相似度则由 Cauchy 形核给出:

$$\begin{aligned} u_{i,j} &= (1 + r_{i,j}^2)^{-1}, & \mathcal{Z} &= \sum_{a \neq b} u_{a,b}, \\ q_{i,j} &= \frac{u_{i,j}}{\mathcal{Z}}, & i &\neq j, \\ q_{i,i} &= 0, & \sum_{i \neq j} q_{i,j} &= 1. \end{aligned} \quad (5.53)$$

$u_{i,j}$ 与自由度为 1 的一维 Student t 分布有相同核形状, 但 $q_{i,j}$ 是有限有序点对上的离散概率, 不是 $\mathbb{R}^k$ 上的多元 Cauchy 密度。它允许较远点仍有一定相似度, 而不要求高低维距离相等。

记 $\mathbf{P} = (p_{i,j})$ 、 $\mathbf{Q} = (q_{i,j})$, t-SNE 最小化

$$C_{\text{tSNE}}(\mathbf{Z}) = \sum_{i \neq j} p_{i,j} \log \frac{p_{i,j}}{q_{i,j}}. \quad (5.54)$$

这里不再是 n 个分别归一化的条件分布。一个点移动会改变 $\mathcal{Z}$ 及其他点对的概率, 因此所有点必须在共同的概率预算下协调位置。

目标优先避免把高概率邻居拉远, 却不要求还原簇间距离、面积或密度。小 $p_{i,j}$ 的点对吸引很弱, 但仍参与归一化并产生斥力; 偏重局部结构不等于忽略远点。

5.3.6.2 参数学习

将式(5.53)代入目标, 并利用 $\sum_{i \neq j} p_{i,j} = 1$, 可把与坐标有关的部分展开为

$$\begin{aligned} C_{\text{tSNE}} &= \text{常数} + \sum_{a \neq b} p_{a,b} \log(1 + r_{a,b}^2) + \log \mathcal{Z}, \\ \nabla_{\mathbf{z}_i} \mathcal{Z} &= -4 \sum_{j \neq i} u_{i,j}^2 (\mathbf{z}_i - \mathbf{z}_j), \\ \nabla_{\mathbf{z}_i} \log \mathcal{Z} &= -4 \sum_{j \neq i} q_{i,j} u_{i,j} (\mathbf{z}_i - \mathbf{z}_j). \end{aligned} \quad (5.55)$$

距离平方求导给出因子 2, 有序对中的两个方向再给出一个因子 2。同理, 第二项的梯度为 $4 \sum_{j \neq i} p_{i,j} u_{i,j} (\mathbf{z}_i - \mathbf{z}_j)$ 。于是

$$\nabla_{\mathbf{z}_i} C_{\text{tSNE}} = 4 \sum_{j \neq i} (p_{i,j} - q_{i,j}) u_{i,j} (\mathbf{z}_i - \mathbf{z}_j). \quad (5.56)$$

当 $p_{i,j} > q_{i,j}$ 时, 负梯度把 i 拉向 j ; 反之推开。即使稀疏近似令 $p_{i,j} = 0$, 有限距离下 $q_{i,j} > 0$, 斥力仍然存在。实际移动是所有点对作用的合成。

早期夸大 (early exaggeration) 在初始若干轮中把梯度里的 $p_{i,j}$ 替换成 $\alpha p_{i,j}$, $\alpha > 1$, 只增强吸引, 随后恢复 $\alpha = 1$ 。原论文取 $\alpha = 4$, 后续也常用 12; 选择需结合学习率和样本规模。夸大权重的总和为 α , 故这一更新

不能仍解释为原归一化分布间 KL 散度的梯度。

动量有助于优化，但不保证逃离局部极小值。PCA 初始化以缩放后的主成分提供有结构的起点，随机初始化则不带这些信息。宏观布局因此也受初始化影响，不能把算法间全部差异归功于目标函数。运行时应记录困惑度、学习率、初始化及夸大系数和持续轮数。

原始算法每轮为 $O(n^2)$ 。Barnes-Hut t-SNE 稀疏化吸引关系，用低维树结构把远点组聚合为位置和总权重，近似其斥力；二维中常用四叉树。固定近邻预算和近似精度、嵌入维数较小时，每轮典型代价为 $O(n \log n)$ ，但建图和极端布局仍影响时间⁴⁹。

Fit-SNE 把核求和转到插值网格上，再用快速傅里叶变换加速卷积⁵⁰。固定插值阶数时，斥力计算约为 $O(n + g \log g)$ ， g 是网格节点数，另需计算稀疏吸引项。网格随范围和精度变化，不能无条件视为常数。2019 年的原工作展示了百万级单细胞数据的处理，但不构成统一的规模上限或速度倍数。

5.3.6.3 理论分析

收敛性分析 t-SNE 仍然非凸，重尾核没有带来全局最优保证。Linderman 与 Steinerberger 的 2019 年 SIAM 期刊论文，在输入相似度具有适当簇结构、初始嵌入集中、夸大系数和步长满足条件时，分析早期簇内收缩及其与谱聚类的联系。这不是任意数据或整个训练过程的谱等价定理⁵¹。

初始点间距很小时， $u_{i,j} \approx 1$ ；若相关斥力扰动相对较小，暂不计动量，更新近似为

$$\begin{aligned} \mathbf{Z}^{(t+1)} &\approx (\mathbf{I} - 4\eta_t \alpha \mathbf{L}_P) \mathbf{Z}^{(t)}, \\ \mathbf{L}_P &= \mathbf{D}_P - \mathbf{P}, \quad (\mathbf{D}_P)_{i,i} = \sum_{j \neq i} p_{i,j}. \end{aligned} \quad (5.57)$$

$\mathbf{D}_P$ 为对角矩阵。合适步长下，图平滑衰减变化快的方向，因而与拉普拉斯谱有关。但点云展开后，核接近 1 的近似可能失效，斥力也不可忽略；反复平滑更不等于直接提取特征向量。关闭夸大后，吸引和斥力仍共同调整布局。

泛化分析 困惑度改变 $\mathbf{P}$ ，也改变问题本身。小困惑度强调细邻域，可能割裂连续结构；大困惑度引入更广关系，也可能模糊稀有群体。可在可达范围内比较 5、30、50 等尺度和多次初始化，检查稳定关系。由于目标分布不同，不能直接按不同困惑度下的 KL 数值排名。

整体旋转和镜像通常无解释意义，簇间距、面积和疏密也不能直接还原为输入量。大簇可能被展开，小簇可能被压紧，连续变化可能呈现为分离区域。单细胞、文本或图像特征中的可视化分组，需要回到合适的高维表示，并按第 4.10 节区分内部指标、稳定性、参考标签和下游任务等证据。

⁴⁹ L. van der Maaten, *Accelerating t-SNE using Tree-Based Algorithms* In Journal of Machine Learning Research, 2014, vol. 15, no. 93, pp. 3221–3245

⁵⁰ G. C. Linderman, M. Rachh, J. G. Hoskins, S. Steinerberger, Y. Kluger, *Fast Interpolation-Based t-SNE for Improved Visualization of Single-Cell RNA-seq Data* In Nature Methods, 2019, vol. 16, no. 3, pp. 243–245

⁵¹ G. C. Linderman, S. Steinerberger, *Clustering with t-SNE, Provably* In SIAM Journal on Mathematics of Data Science, 2019, vol. 1, no. 2, pp. 313–332

原始 t-SNE 没有显式样本外映射，但 openTSNE 等实现可固定参考嵌入，根据新样本与参考样本的相似度优化新点。这是给定参考布局的条件嵌入，不等于新旧样本联合重训，也不保证训练集缺失的新群体被正确安排⁵²。

反复嵌入新样本时，可令 $\mathbf{z}_i = f_{\theta}(\mathbf{x}_i)$ ，按邻域目标学习网络参数 θ 。van der Maaten 的 2009 年参数化 t-SNE 允许前向计算新点，但批次构造和概率归一化影响训练关系，网络函数族也限制可实现的布局⁵³。

5.3.6.4 小结

t-SNE 以对称点对概率简化匹配，用重尾核缓解拥挤，适合探索局部相似性，但不是可直接测量的全局地图。计算加速和样本外扩展分别改善效率与使用方式，都不消除非凸优化和结构保真的限制。

5.3.7 UMAP

除了全局归一化，也可以分别描述每条邻接关系有多强。**统一流形逼近与投影** (uniform manifold approximation and projection, UMAP) 据此构造局部加权图，再优化低维布局。

McInnes、Healy 与 Melville 从 2018 年起公开的方法长文，将拉普拉斯特征映射、黎曼几何与模糊拓扑联系起来，重点讨论实际样本不均匀时如何调整局部度量，以及如何合并不同局部描述⁵⁴。这一问题设置也面向机器学习预处理中的较高维表示，并不限于二维画图。方法长文与同年的 JOSS 软件论文是不同文献；其几何构造、软件实现和可视化效果也需要分别评价。

5.3.7.1 模型结构

记 q 个近邻的索引集为 $N_q(i)$ ，不包含 i 。先假设样本互异、最近邻无并列，局部连接参数采用单位设置。令 $\rho_i = \min_{j \neq i} \delta_{i,j}$ ，定义

$$v_{j|i} = \begin{cases} \exp\left(-\frac{\max(0, \delta_{i,j} - \rho_i)}{\sigma_i}\right), & j \in N_q(i), \\ 0, & j \notin N_q(i), \end{cases} \quad (5.58)$$

$$\sum_{j \in N_q(i)} v_{j|i} = \log_2 q.$$

ρ_i 使最近邻权重为 1， σ_i 控制其余连接的衰减。可按任务更换距离度量，但需重审几何解释。当 $q > 2$ 且上述条件成立时，权重和随正带宽从 1 向 q 增长，可以搜索到目标值。

$v_{j|i}$ 是边的隶属强度，各边可同时很强，行和不是 1。 $\log_2 q$ 是尺度校准

⁵² P. G. Poličar, M. Stražar, B. Zupan, *openTSNE: A Modular Python Library for t-SNE Dimensionality Reduction and Embedding* In Journal of Statistical Software, 2024, vol. 109, no. 3, pp. 1–30

⁵³ L. van der Maaten, *Learning a Parametric Embedding by Preserving Local Structure* In Proceedings of the Twelfth International Conference on Artificial Intelligence and Statistics, 2009, pp. 384–391

⁵⁴ L. McInnes, J. Healy, J. Melville, *UMAP: Uniform Manifold Approximation and Projection for Dimension Reduction*, 2018, arXiv: 1802.03426, URL: <https://arxiv.org/abs/1802.03426>

目标，并非熵或困惑度。重复样本、并列近邻或其他局部连接设置可能使多条边固定为 1，导致目标不可达；实现需要零距离处理、带宽下界和容差。

两个方向的局部判断用模糊并集合并：

$$v_{i,j} = v_{j|i} + v_{i|j} - v_{j|i}v_{i|j}. \quad (5.59)$$

结果满足 $v_{i,j} = v_{j,i} \in [0, 1]$ 。一个方向为 1 时，合并权重为 1；两个方向都是 0.4 时，合并为 0.64，既非平均也非全局归一化。它采用模糊集合运算，无须假定两条有向边是独立随机事件。

模糊单纯集 (fuzzy simplicial set) 提供更一般的描述：以点、边、三角面等组合结构表达空间，并赋予隶属强度。范畴论框架解释局部观察如何组合，实际目标主要使用一维骨架，即样本和加权边。这种有限样本表示不保证图中每个环或空白都对应真实拓扑。

低维连接采用可调的重尾函数

$$w_{i,j} = \frac{1}{1 + ar_{i,j}^{2b}}, \quad a > 0, \quad b > 0. \quad (5.60)$$

a 、 b 由 `min_dist` 和 `spread` 确定，用光滑核逼近近处接近 1、超过指定尺度后衰减的目标曲线。`min_dist` 是软紧凑参数，并非所有点间距的硬下界。当 $a = b = 1$ 时， $w_{i,j}$ 仅与 t-SNE 的未归一化核 $u_{i,j}$ 相同，没有除以 z ，故不等于 $q_{i,j}$ 。

为了让高维和低维的边强度接近，可把每条边看成一次带软标签的二元判断。对无序对 $i < j$ ，完整目标写成

$$C_B(\mathbf{Z}) = \sum_{i < j} \left[v_{i,j} \log \frac{v_{i,j}}{w_{i,j}} + (1 - v_{i,j}) \log \frac{1 - v_{i,j}}{1 - w_{i,j}} \right]. \quad (5.61)$$

这是逐边 Bernoulli 分布的 KL 散度之和。去掉只依赖 $v_{i,j}$ 的常数项，得到二元交叉熵

$$C_{CE}(\mathbf{Z}) = - \sum_{i < j} [v_{i,j} \log w_{i,j} + (1 - v_{i,j}) \log(1 - w_{i,j})]. \quad (5.62)$$

采用 $0 \log 0 = 0$ 约定。两式对 $\mathbf{Z}$ 有相同梯度；与 t-SNE 的区别不在“交叉熵对 KL”，而在逐边二元匹配与全局归一化点对匹配。

第一项拉近有边的点，第二项阻止非邻居贴近。但零权重只表示没有保留局部连接，相距稍远和极远都可能得到 $v_{i,j} = 0$ ；非边项因此不保证全局距离保真。

5.3.7.2 参数学习

定义吸引损失 $\ell_{i,j}^+ = -\log w_{i,j}$ 和排斥损失 $\ell_{i,j}^- = -\log(1 - w_{i,j})$ 。当 $r_{i,j} > 0$ 时,

$$\begin{aligned}\nabla_{\mathbf{z}_i} \ell_{i,j}^+ &= \frac{2abr_{i,j}^{2b-2}}{1 + ar_{i,j}^{2b}}(\mathbf{z}_i - \mathbf{z}_j), \\ \nabla_{\mathbf{z}_i} \ell_{i,j}^- &= -\frac{2b}{r_{i,j}^2(1 + ar_{i,j}^{2b})}(\mathbf{z}_i - \mathbf{z}_j).\end{aligned}\quad (5.63)$$

负梯度分别拉近和推开点, 完整交叉熵再用 $v_{i,j}$ 和 $1 - v_{i,j}$ 加权。重合附近的排斥项有奇异性, 实现需作数值稳定处理并限制过大更新。

遍历全部点对仍需二次方计算。UMAP 用**负采样** (negative sampling) 加速: 按正边权重安排吸引更新, 再对中心点抽取 s 个排斥对象; 抽样并非逐一核验非邻居。若图有 $O(nq)$ 条边, 每边每轮更新次数有界, 固定 k 时一轮约为 $O(nq(1+s))$ 。只有 q, s 固定时才近似线性, 且不包括建图和总轮数。

中心点被抽到的机会依赖正边权重, 负样本的机会依赖采样分布。没有相应的重要性修正, 期望更新不等于完整交叉熵梯度; 负采样改变了吸引和排斥比例, 并非无偏地少算一些非边。

Damrich 与 Hamprecht 于 2021 年分析这一过程。记加权重 $\omega_i = \sum_{j \neq i} v_{i,j}$ 。在其均匀负采样模型中, 若每次排斥都更新双端, 略去共同正常数后, 有效目标为

$$\begin{aligned}\tilde{C}(\mathbf{Z}) &= \sum_{i < j} [v_{i,j} \ell_{i,j}^+ + \gamma_{i,j} \ell_{i,j}^-], \\ \gamma_{i,j} &= \frac{s(\omega_i + \omega_j)}{2n}.\end{aligned}\quad (5.64)$$

排斥权重不再是 $1 - v_{i,j}$, 而依赖样本数、加权重和负采样数。论文所分析的非参数实现仅移动排斥对的一端, 期望更新一般甚至不对应标量损失的梯度; 式(5.64)对应补上双端更新的版本, 必须保留这一条件⁵⁵。

若 $w_{i,j}$ 可独立选择, 逐对最优值为 $v_{i,j}/(v_{i,j} + \gamma_{i,j})$ 。正边权重远大于 $\gamma_{i,j}$ 时, 最优值接近 1, 有助于解释紧凑布局的倾向。但坐标耦合了所有权重, 未必能同时达到逐对最优值。

实际流程依次完成近邻搜索、尺度估计、模糊并图、初始化和采样更新。可用谱或随机初始化; 图不连通时, 各分量相对位置缺少约束。学习率通常逐渐衰减, 采样数和排斥强度也影响结果, 不能只关注两个主要超参数。

`n_neighbors` 控制建图尺度, 大值加入更广连接, 但不保证全局指标单调改善。`min_dist` 小则允许更紧的群组, 大则通常更分散。`umap-learn` 常用的 $q = 15$ 和 `min_dist=0.1` 只是起点, 还需记录度量、维数、轮数、

⁵⁵ S. Damrich, F. A. Hamprecht, *On UMAP's True Loss Function* In *Advances in Neural Information Processing Systems*, 2021, pp. 5798–5809

种子和版本⁵⁶。

5.3.7.3 理论分析

收敛性分析 完整交叉熵和有效目标对坐标都非凸，近邻近似、有限轮随机更新和梯度裁剪又引入额外差异。驻点结论不等于最佳拓扑布局保证。负采样分析强调有效吸引与排斥，并不证明 UMAP 等价于非负矩阵分解，也不证明它比 t-SNE 更保留全局结构。

泛化分析 局部流形近似、尺度调整和模糊拓扑拼接解释了 UMAP 如何建图，却不保证任意有限样本的二维结果保留全局结构。光滑流形、合适局部度量和充分采样等假设需要检验；理论构造、近似建图和采样优化的保证不能跨层直接套用。

UMAP 的 `transform` 在训练集中寻找新样本的近邻，以邻居坐标初始化，再固定参考嵌入、优化新点。这是条件定位，不是显式解析映射或新旧坐标联合重训。新数据与训练分布接近时，可放入同一参考图；出现新类别或分布漂移时，位置可能失真。

另一条路线是学习从输入到嵌入的共享函数。Sainburg、McInnes 与 Gentner 的参数化 UMAP 将正负样本训练与网络结合，支持小批次和半监督学习；它不同于固定参考坐标后优化新点的 `transform`。前向推断更直接，但不天然保证分布外泛化或复现全部非参数布局细节⁵⁷。

先拟合子样本、再变换其余样本可以降低计算负担，但子样本需覆盖稀有群体等重要结构。用于下游预测时，应只在训练划分内拟合预处理和嵌入，再变换验证集和测试集，避免结构泄漏。图形美观与预测效果是不同问题。

5.3.7.4 小结

UMAP 以局部尺度和模糊并建图，用可调核布局，以采样控制计算。模糊边权、匹配目标和有效更新必须区分。参考图变换虽方便，结果仍受度量、建图、初始化及采样影响，紧凑图形不等于可靠结构。

5.3.8 模型对比与总结

表5.2回顾前述线性与核、距离和邻域方法，按输入、保留对象和求解方式比较六种代表方法。它们都可以处理关系数据，但不都依赖流形假设，也不都归结为一次特征分解：应力型 MDS 是明显例外。复杂度应按稠密矩阵、稀疏图和近似方案分别讨论，而不是给每个方法贴一个固定阶数。

选择方法时，需要先确定误差的含义。感知评分可用度量或非度量 MDS，非线性预处理可考察核 PCA；若潜在区域可展开且长度有意义，Isomap

⁵⁶ L. McInnes, J. Healy, N. Saul, L. Großberger, *UMAP: Uniform Manifold Approximation and Projection* In *Journal of Open Source Software*, 2018, vol. 3, no. 29, pp. 861

⁵⁷ T. Sainburg, L. McInnes, T. Q. Gentner, *Parametric UMAP Embeddings for Representation and Semisupervised Learning* In *Neural Computation*, 2021, vol. 33, no. 11, pp. 2881–2907

方法	输入与保留对象	核心求解	样本外使用与主要限制
MDS	给定差异；经典拟合内积，应力型拟合距离或顺序	经典型取正谱；度量及非度量应力通常迭代求解	需要到训练点的差异；非欧氏性与目标维数限制保真程度
核 PCA	正定核；特征空间方差	中心化核矩阵的主特征方向	核投影有明确公式；依赖训练中心化、核尺度和谱隙
Isomap	邻域图；全局测地距离的估计	最短路径后做经典 MDS	接入图后做距离扩展；短路、断连及不可展开几何会失真
LLE	邻居与局部重构权；仿射重构关系	局部线性方程与全局低端谱	局部权重插值；病态邻域、多零模态与噪声需诊断
Laplacian Eigenmaps	对称非负邻域权重；图上平滑性	度加权广义特征值问题	可作谱延拓；度、密度、断连影响低频表示
Diffusion Map	对称权重及重加权；给定步数的扩散距离	可逆转移矩阵的谱与时间加权	Nyström 延拓；截断、带宽和过度混合限制区分能力

表 5.2 六类方法在本节所述标准构造下的比较。MDS 一行区分经典型与应力型，不能把二者的目标和求解混同。样本外一栏均指固定训练表示后的扩展，不代表加入新样本重新训练的等价结果，也不是预测性能保证。

提供相应的距离模型。局部仿射关系可信时可考察 LLE，图上平滑性是重点时可用拉普拉斯坐标，跨时间尺度的概率连通性则由扩散距离描述。动力系统分析只有在构图与所关心的动力过程相符时，才能把慢扩散模态解释为相关的慢变量，不能仅凭数据来自时间序列作出这一判断。

这些方法还对应不同的扩展方向。**Hessian LLE** 亦称 Hessian 特征映射，估计局部坐标中函数的二阶变化，并寻找其平方积分接近零的方向。在连通、局部等距于欧氏区域等条件下，仿射坐标具有零 Hessian；原理论允许某些非凸、带孔的参数区域，不等于任意带孔流形都能无失真恢复。离散方法还需要足够多且分布合适的邻居来估计二阶项，通常比一阶局部拟合更依赖采样条件⁵⁸。

局部切空间对齐 (local tangent space alignment, LTSA) 先在每个邻域做局部 PCA，估计 m 维切空间及局部坐标，再选择一组全局坐标，使其在各邻域中能通过局部仿射变换与切空间坐标对齐。这把 LLE 中隐含的局部线性结构显式化，但切空间估计误差和不适当的邻域仍会传播到全局结果⁵⁹。

最大方差展开 (maximum variance unfolding, MVU) 则把局部距离直接写成约束，学习未知 Gram 矩阵 B ：

$$\max_{B \geq 0} \quad \text{tr}(B), \quad B\mathbf{1} = \mathbf{0},$$

$$\text{满足} \quad B_{i,i} + B_{j,j} - 2B_{i,j} = \|\mathbf{x}_i - \mathbf{x}_j\|_2^2, \quad (i, j) \in E.$$

中心化下，增大迹相当于在保持局部边长时增大全体点的总方差。这是半正定规划，凸的是 Gram 矩阵优化，不是额外施加固定秩后的任意低维问题。最优矩阵未必恰好秩为 k ，谱截断后局部约束也可能不再精确；规模较大时，半正定求解本身是主要成本⁶⁰。

⁵⁸ D. L. Donoho, C. Grimes, *Hessian Eigenmaps: Locally Linear Embedding Techniques for High-Dimensional Data* In Proceedings of the National Academy of Sciences, 2003, vol. 100, no. 10, pp. 5591–5596

⁵⁹ Z. Zhang, H. Zha, *Principal Manifolds and Nonlinear Dimensionality Reduction via Tangent Space Alignment* In SIAM Journal on Scientific Computing, 2004, vol. 26, no. 1, pp. 313–338

⁶⁰ K. Q. Weinberger, L. K. Saul, *Unsupervised Learning of Image Manifolds by Semidefinite Programming* In International Journal of Computer Vision, 2006, vol. 70, no. 1, pp. 77–90

比较方面	SNE	t-SNE	UMAP
高维对象	逐点条件邻居概率	对称联合点对概率	稀疏模糊邻域图权重
低维对象	行归一化高斯核	全局归一化重尾核	不作概率归一化的可调重尾权重
建模依据	条件分布匹配	点对分布匹配	局部几何与模糊图构造
优化目标	条件 KL 散度之和	联合 KL 散度	逐边交叉熵；负采样改变有效目标
邻域尺度	困惑度及逐点带宽	困惑度及逐点带宽	邻居数 q 、局部距离偏移和带宽
布局控制	初始化、学习率等	初始化、夸大、学习率等	初始化、核形状、采样和排斥等
迭代代价	稠密计算 $O(n^2)$	稠密 $O(n^2)$ ；树或插值可加速	固定嵌入维数下约 $O(nq(1+s))$
全局解释	不保证距离或密度保真	簇间距、面积不宜直接解释	图连接提供约束，但不保证全局保真
收敛边界	非凸、依赖初始化	非凸；部分早期阶段有条件分析	非凸；依赖实际采样更新规则
新样本	需另定义扩展	参考图扩展或参数化版本	transform 或参数化版本

表 5.3 三种邻域降维方法。复杂度指固定嵌入维数下的一轮优化，不含建图和总轮数； s 为每次正边更新的负采样数。

向量扩散映射（vector diffusion maps）由邻域切空间之间的正交对齐矩阵替代纯标量权重的一部分作用，使路径上的方向运输也参与比较⁶¹。其连续联系是连接拉普拉斯算子，即作用于向量场而非标量函数的几何算子。它补充的是方向一致性信息，并非普通扩散距离在所有任务上的更好替代。

这些联系不宜扩张成“所有非线性降维都是换一种距离做 MDS”。例如，高斯过程潜变量模型通过从潜变量到观测的概率映射和似然学习表示，不是通常意义下把某种概率距离交给经典 MDS。类似地，t-SNE、UMAP 侧重邻域关系的低维呈现，但不能据此认定它们全面取代几何方法，或把 UMAP 在未说明的极限下直接等同于拉普拉斯能量。SNE、t-SNE 和 UMAP 同样需要用各自目标解释簇间距离和视觉分离。

本节开头的问题因此有了一个带条件的答案：非线性降维不是单纯把弯曲数据“压平”，而是选择可信的关系，再接受目标维数能够保留的部分。核、邻域、归一化和时间尺度决定了关系本身；数值求解正确、训练目标小、流形极限存在与下游任务有效，是需要分别验证的四件事。

表5.3比较三种方法的机制与边界，不作脱离数据的排名。t-SNE 的困惑度是有效邻居数，UMAP 的 q 是建图邻居数，两者作用相似但不能直接换算。

速度比较需固定近邻搜索、精度、硬件、线程数和优化预算，不能把近似实现与稠密实现的差距当成普遍倍数。可复现性还依赖预处理、初始化、版本和并行方式；固定种子便于重复运行，多种子、多尺度检查才有助于辨别稳定结构。

⁶¹ A. Singer, H.-T. Wu, *Vector Diffusion Maps and the Connection Laplacian* In Communications on Pure and Applied Mathematics, 2012, vol. 65, no. 8, pp. 1067–1144

扩展方法可改变建图、约束或映射。Tang 等人的 LargeVis 用随机投影树和邻居探索构造近似近邻图，再以概率化图布局和负采样优化吸引与排斥⁶²。它结合了可扩展建图和布局，但不是无偏求解原 SNE 条件 KL 目标的加速版。

局部群组之间可能缺少相对位置约束。Wang 等人的 PaCMAP 在近邻对、较远点对之外加入中距离对，并随优化阶段调整作用权重，以组织较大尺度的联系⁶³。其效果还依赖损失形状、配对和初始化，实验中的全局指标改善不是普遍保证。

Amid 与 Warmuth 于 2019 年提出的 TriMap 用三元组 (i, j, ℓ) 要求 j 比 ℓ 更接近 i ，通过跨尺度采样和加权损失编码相对关系⁶⁴。它保留所抽取的排序而非全部距离，三元组选择和初始化仍影响结果。

流形学习与邻域嵌入不是“几何对概率”的互斥分类：LLE 和拉普拉斯特征映射也用局部图，UMAP 也借助流形建模。应按约束量、近似方式和使用目标选择方法。研究测地关系可考察 Isomap，探索相似样本组织可比较 t-SNE 和 UMAP；用于下游特征时还应考虑 $k > 2$ 并验证任务效果，不把二维图直接当成最佳表示。

邻域嵌入把有限的低维表达能力优先用于重要邻接关系，回答了开篇的取舍问题。图形可以提出假设、展示独立分析支持的结构，却不能直接确定原数据的簇数量、大小或间隔。聚类应在原始或合适的高维表示中验证，并结合不同尺度、初始化和领域知识检查。图中所见只有经过这些核实验，才能成为分析证据。

5.4 基于概率的降维

本节使用第1.2.4节的潜变量生成视角：从低维坐标到观测规定映射及噪声，再根据观测推断坐标。PPCA、因子分析与 GPLVM 的差异在于生成映射、噪声结构，以及哪些未知量保留后验不确定性。沿用章首的 n, d, k 和输入矩阵 $\mathbf{X}$ 。

5.4.1 概率主成分分析（PPCA）与因子分析

几个传感器共同测量低维状态，读数又带有误差，这就需要区分共同变化与噪声。**概率主成分分析**（probabilistic principal component analysis, PPCA）用低维高斯状态生成线性信号，再加入同方差高斯噪声。

允许各观测坐标具有不同噪声方差，就得到本节的高斯**因子分析**（factor analysis, FA）；“因子”是解释共同变化的潜变量。其历史可追溯到 Spearman 于 1904 年的一般智力研究，但现代多因子模型不等同于当时的心理测量假说⁶⁵。

⁶² J. Tang, J. Liu, M. Zhang, Q. Mei, *Visualizing Large-Scale and High-Dimensional Data* In Proceedings of the 25th International Conference on World Wide Web, 2016, pp. 287–297

⁶³ Y. Wang, H. Huang, C. Rudin, Y. Shaposhnik, *Understanding How Dimension Reduction Tools Work: An Empirical Approach to Deciphering t-SNE, UMAP, TriMap, and PaCMAP for Data Visualization* In Journal of Machine Learning Research, 2021, vol. 22, no. 201, pp. 1–73

⁶⁴ E. Amid, M. K. Warmuth, *TriMap: Large-Scale Dimensionality Reduction Using Triplets*, 2019, arXiv: 1910.00204, URL: <https://arxiv.org/abs/1910.00204>

⁶⁵ C. Spearman, “General Intelligence,” *Objectively Determined and Measured* In The American Journal of Psychology, 1904, vol. 15, no. 2, pp. 201–292

Tipping 与 Bishop 在 1999 年重新考察 PCA 时, 关注的是其常见几何定义尚未为观测规定概率模型。他们用与因子分析密切相关的潜变量模型刻画主子空间, 同时研究似然性质和 EM 估计方法⁶⁶。这样, 特征分解与潜变量的迭代估计便能在同一似然目标下比较, 几何压缩也获得了处理噪声和缺失观测的统计工具。

5.4.1.1 模型结构

设 $\mathbf{z} \in \mathbb{R}^k$ 为潜变量, $\mathbf{W} \in \mathbb{R}^{d \times k}$ 为载荷矩阵, $\boldsymbol{\mu} \in \mathbb{R}^d$ 为均值。PPCA 取 $1 \leq k < d$, 并假设

$$\begin{aligned} \mathbf{z} &\sim \mathcal{N}(\mathbf{0}, \mathbf{I}_k), \\ \mathbf{x} &= \boldsymbol{\mu} + \mathbf{W}\mathbf{z} + \boldsymbol{\epsilon}, \\ \boldsymbol{\epsilon} &\sim \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I}_d), \quad \boldsymbol{\epsilon} \perp \mathbf{z}, \quad \sigma^2 > 0. \end{aligned} \quad (5.65)$$

各向同性只限制噪声, 不要求观测总方差相等。固定 $\mathbf{z}$ 后, 条件负对数似然包含 $\|\mathbf{x} - \boldsymbol{\mu} - \mathbf{W}\mathbf{z}\|_2^2 / (2\sigma^2)$, 解释了平方误差的来源; 边缘似然还要对 $\mathbf{z}$ 积分。

图 5.10 用结构示意图区分生成与推断: 生成时抽取潜变量并加入噪声, 降维时给定观测计算后验。




图 5.10 概率生成与后验推断的结构示意。实线表示 $\mathbf{z} \rightarrow \mathbf{x}$ 的生成方向; 虚线表示 $\mathbf{x} \rightarrow \mathbf{z}$ 的后验推断, 不是额外的生成依赖。图中节点与箭头只说明变量角色和条件关系, 不表示实测数据、网络层数或计算流程; 噪声描述观测对信号的偏离, 不是新增的潜变量维数。

独立高斯量的线性组合仍是高斯量, 因而积分掉潜变量后有

$$\begin{aligned} p(\mathbf{x}) &= \mathcal{N}(\mathbf{x}; \boldsymbol{\mu}, \mathbf{C}), \\ \mathbf{C} &= \mathbf{W}\mathbf{W}^\top + \sigma^2 \mathbf{I}_d. \end{aligned} \quad (5.66)$$

信号协方差的秩至多为 k , 正噪声保证 $\mathbf{C}$ 正定, 即使经验协方差因样本不足而奇异。

FA 改用 $\boldsymbol{\Psi} = \text{diag}(\psi_1, \dots, \psi_d)$, 其中 $\psi_j > 0$ 表示方差, 于是 $\mathbf{C} = \mathbf{W}\mathbf{W}^\top + \boldsymbol{\Psi}$ 。

⁶⁶ M. E. Tipping, C. M. Bishop, *Probabilistic Principal Component Analysis* In Journal of the Royal Statistical Society: Series B (Statistical Methodology), 1999, vol. 61, no. 3, pp. 611–622

给定因子后，各维条件独立，跨维协方差由共同因子解释。独特方差还可包含特征特有的变化，不必全是仪器误差；标准化也会改变同方差假设的含义。

图5.11固定相同的载荷，只改变噪声。给定一个潜变量取值后，PPCA允许观测向各个方向等幅偏离条件均值，FA则允许沿某个观测坐标偏离更多。图中的圆和椭圆表示条件噪声；把不同潜变量取值混合以后，还要加上沿载荷方向变化的信号协方差，才得到全部观测的分布。




图 5.11 PPCA 与 FA 的条件噪声示意。设 $d = 2$ 、 $k = 1$ 、 $\mu = \mathbf{0}$ 、 $\mathbf{W} = (1, 0.6)^\top$ ，三个实心点对应 $z = -1, 0, 1$ 的条件均值。左图取 $\sigma = 0.28$ ，右图取 $\Psi = \text{diag}(0.16^2, 0.50^2)$ ；每条轮廓到其中心的平方 Mahalanobis 距离均为 1。坐标为无量纲构造值，轮廓是条件等密度线，不是总体数据云或置信区域。

正交旋转 $\mathbf{WR}$ 不改变协方差。载荷满列秩且除旋转外局部可识别时，扣除 $k(k-1)/2$ 个旋转自由度，PPCA 和 FA 的协方差参数数目分别为 $dk + 1 - k(k-1)/2$ 和 $dk + d - k(k-1)/2$ ，均值另占 d 个。FA 还须排除载荷与噪声间的额外不可识别性。相比自由协方差的 $d(d+1)/2$ 个参数，小 k 约束可能降低估计方差，也可能引入偏差。

5.4.1.2 参数学习

假设样本独立同分布。记样本均值为 $\bar{\mathbf{x}}$ ， $\mathbf{y}_i = \mathbf{x}_i - \bar{\mathbf{x}}$ ， $\mathbf{S} = n^{-1} \sum_i \mathbf{y}_i \mathbf{y}_i^\top$ ，分母采用最大似然所需的 n 。固定 $\mathbf{C}$ 时，均值梯度为 $n\mathbf{C}^{-1}(\bar{\mathbf{x}} - \mu)$ ，二阶导数负定，故 $\hat{\mu} = \bar{\mathbf{x}}$ 。代回得

$$\ell = -\frac{n}{2} \left[d \log(2\pi) + \log |\mathbf{C}| + \text{tr}(\mathbf{C}^{-1} \mathbf{S}) \right]. \quad (5.67)$$

对数行列式限制分布过度扩散，迹项限制数据变化较大的方向上方差过小。

记 $\mathbf{S} = \mathbf{U} \mathbf{\Lambda} \mathbf{U}^\top$ ， $\lambda_1 \geq \dots \geq \lambda_d \geq 0$ ， $\mathbf{U}_k$ 取前 k 个特征向量， $\mathbf{\Lambda}_k = \text{diag}(\lambda_1, \dots, \lambda_k)$ 。

下面的证明会用到 Birkhoff-von Neumann 分解：双随机矩阵是行和、列和都为 1 的非负方阵，每个有限维双随机矩阵都可写成置换矩阵的凸组

合⁶⁷。因此，对它取值的线性目标不小于所有置换取值中的最小者。

主线阅读可先保留最大似然解的结构：载荷张成 PCA 主子空间，噪声方差取被舍弃样本特征值的均值，载荷内部仍可旋转。进阶证明先用双随机分解证明样本谱与模型谱应同序对齐，再逐项优化谱值；这解释全局最优性，但不会自动给出奇异点或高维渐近下的统计保证。

⁶⁷ G. Birkhoff, *Tres observaciones sobre el álgebra lineal* In Universidad Nacional de Tucumán. Revista. Serie A, 1946, vol. 5, pp. 147–151

定理 5.8 PPCA 的最大似然解 设 $1 \leq k < d$ ，尾谱均值 $\tau = (d - k)^{-1} \sum_{j=k+1}^d \lambda_j$ 满足 $\tau > 0$ 且 $\lambda_k > \tau$ 。在 $\sigma^2 > 0$ 的 PPCA 模型中，以下参数达到全局最大似然：

$$\begin{aligned} \hat{\boldsymbol{\mu}} &= \bar{\mathbf{x}}, & \hat{\sigma}^2 &= \tau, \\ \hat{\mathbf{W}} &= \mathbf{U}_k (\boldsymbol{\Lambda}_k - \tau \mathbf{I}_k)^{1/2} \mathbf{R}. \end{aligned} \quad (5.68)$$

其中 $\mathbf{R}$ 为任意 k 阶正交矩阵。截断处有重根时， $\mathbf{U}_k$ 可在对应特征子空间内选取不同正交方向。

证明. 需最小化 $F(\mathbf{C}) = \log |\mathbf{C}| + \text{tr}(\mathbf{C}^{-1} \mathbf{S})$ 。写 $s = \sigma^2$ ，由信号半正定且秩至多为 k ，可行协方差的谱满足

$$c_1 \geq \cdots \geq c_k \geq s, \quad c_{k+1} = \cdots = c_d = s > 0.$$

允许 $c_j = s$ 便包括载荷秩不足 k 的情况。

固定谱，设 $\mathbf{p}_b$ 为 $\mathbf{C}$ 的第 b 个单位特征向量，则

$$\text{tr}(\mathbf{C}^{-1} \mathbf{S}) = \sum_{a=1}^d \sum_{b=1}^d \frac{\lambda_a}{c_b} (\mathbf{u}_a^\top \mathbf{p}_b)^2.$$

平方内积构成非负且各行各列和为 1 的双随机矩阵，可写成置换矩阵的凸组合，所以上式不小于置换配对的最小值。若 $\lambda_a \geq \lambda_b$ 、 $c_a \geq c_b$ ，同序配对减去交换配对等于

$$(\lambda_a - \lambda_b) \left(\frac{1}{c_a} - \frac{1}{c_b} \right) \leq 0.$$

消去逆序配对即得 $\text{tr}(\mathbf{C}^{-1} \mathbf{S}) \geq \sum_j \lambda_j / c_j$ ，取 $\mathbf{p}_j = \mathbf{u}_j$ 达到等号。对数行列式只依赖谱，故同序对齐是固定谱下的全局最优。

对齐后，目标化为

$$\begin{aligned} F &= \sum_{j=1}^k \left(\log c_j + \frac{\lambda_j}{c_j} \right) \\ &\quad + (d - k) \log s + \frac{(d - k)\tau}{s}. \end{aligned}$$

暂去 $c_j \geq s$ 及排序约束。对 $a > 0$ ，函数 $g_a(v) = \log v + a/v$ 的导数为 $(v-a)/v^2$ ，在 a 左侧为负、右侧为正，故 $v = a$ 为唯一全局最小点。各首部项因此在 $c_j = \lambda_j$ 处最小，尾部 $(d-k)g_\tau(s)$ 在 $s = \tau$ 处最小。

由 $\lambda_k > \tau > 0$ ，此解满足原约束。式 (5.68) 构造的协方差恰与 $\mathbf{S}$ 同序对齐，首 k 个特征值为 λ_j ，其余为 τ ，达到上述共同下界，故是全局最优。正交 $\mathbf{R}$ 不改变载荷乘积；重根配对差为零，允许所述的不唯一性。 ■

若 $\lambda_k = \tau > 0$ ，同式仍给出最优协方差，但载荷降秩，满秩自由度与常规渐近结论不再直接适用。若 $\tau = 0$ ，则样本协方差秩至多为 k ；让未被数据占据的方向方差趋零，似然无界增大，正噪声空间中无有限极大值。 $\sigma^2 = 0$ 对应奇异高斯分布，不再有 d 维普通密度。

定理统一的是主子空间，不是坐标或整个概率模型。编码观测需要后验，由生成式得到联合高斯分布

$$\begin{bmatrix} \mathbf{z} \\ \mathbf{x} \end{bmatrix} \sim \mathcal{N} \left(\begin{bmatrix} \mathbf{0} \\ \boldsymbol{\mu} \end{bmatrix}, \begin{bmatrix} \mathbf{I}_k & \mathbf{W}^\top \\ \mathbf{W} & \mathbf{C} \end{bmatrix} \right). \quad (5.69)$$

高斯分块条件公式给出后验均值 $\mathbf{W}^\top \mathbf{C}^{-1}(\mathbf{x} - \boldsymbol{\mu})$ 和协方差 $\mathbf{I}_k - \mathbf{W}^\top \mathbf{C}^{-1} \mathbf{W}$ 。定义 $\mathbf{M} = \mathbf{W}^\top \mathbf{W} + \sigma^2 \mathbf{I}_k$ ，由 $\mathbf{C}\mathbf{W} = \mathbf{W}\mathbf{M}$ 可得 $\mathbf{W}^\top \mathbf{C}^{-1} = \mathbf{M}^{-1} \mathbf{W}^\top$ ，因而

$$\mathbf{I}_k - \mathbf{M}^{-1} \mathbf{W}^\top \mathbf{W} = \sigma^2 \mathbf{M}^{-1}.$$

于是后验为

$$p(\mathbf{z} | \mathbf{x}) = \mathcal{N}(\mathbf{M}^{-1} \mathbf{W}^\top (\mathbf{x} - \boldsymbol{\mu}), \sigma^2 \mathbf{M}^{-1}). \quad (5.70)$$

在最大似然解中取 $\mathbf{R} = \mathbf{I}_k$ ，第 j 个后验均值坐标是

$$\mathbb{E}[z_j | \mathbf{x}] = \frac{\sqrt{\lambda_j - \tau}}{\lambda_j} \mathbf{u}_j^\top (\mathbf{x} - \bar{\mathbf{x}}). \quad (5.71)$$

它是 PCA 得分的缩放；映射回观测空间的系数为 $1 - \tau/\lambda_j$ ，也不同于正交重构的 1。例如教学谱 (9, 1, 1) 取 $k = 1$ 时， $\tau = 1$ ，载荷为 $\sqrt{8}\mathbf{u}_1$ ，后验方差为 $1/9$ ，重构系数为 $8/9$ 。

后验协方差不随完整观测 $\mathbf{x}$ 变化，这是线性同方差假设的结果，且不包含参数估计误差。固定满列秩载荷并令噪声趋零，重构才趋于其列空间的正交投影；潜在坐标仍依赖载荷尺度。

FA 通常采用迭代求解。**期望最大化** (expectation-maximization, EM) 交替执行两步：E 步求潜变量后验矩，M 步最大化完全数据对数似然的后验期望；这里“完全数据”包括观测 $\mathbf{x}_i$ 与潜变量 $\mathbf{z}_i$ ，并不表示两者都已记录⁶⁸。

⁶⁸ A. P. Dempster, N. M. Laird, D. B. Rubin, *Maximum Likelihood from Incomplete Data via the EM Algorithm* In Journal of the Royal Statistical Society: Series B (Methodological), 1977, vol. 39, no. 1, pp. 1–38

当每个观测向量的各维均已记录时, 固定 $\mu = \bar{x}$ 。在第 t 次迭代, E 步为

$$\begin{aligned} \mathbf{V}^{(t)} &= \left[\mathbf{I}_k + (\mathbf{W}^{(t)})^\top (\Psi^{(t)})^{-1} \mathbf{W}^{(t)} \right]^{-1}, \\ \mathbf{m}_i^{(t)} &= \mathbf{V}^{(t)} (\mathbf{W}^{(t)})^\top (\Psi^{(t)})^{-1} \mathbf{y}_i, \\ \mathbf{Q}_i^{(t)} &= \mathbf{V}^{(t)} + \mathbf{m}_i^{(t)} (\mathbf{m}_i^{(t)})^\top. \end{aligned} \quad (5.72)$$

其中 $\mathbf{m}_i^{(t)}$ 为后验均值, $\mathbf{V}^{(t)}$ 为协方差, $\mathbf{Q}_i^{(t)}$ 为二阶矩。汇总这些后验矩, 定义

$$\mathbf{A}^{(t)} = \frac{1}{n} \sum_i \mathbf{y}_i (\mathbf{m}_i^{(t)})^\top, \quad \mathbf{B}^{(t)} = \frac{1}{n} \sum_i \mathbf{Q}_i^{(t)}.$$

M 步利用这些统计量更新载荷与噪声:

$$\begin{aligned} \mathbf{W}^{(t+1)} &= \mathbf{A}^{(t)} (\mathbf{B}^{(t)})^{-1}, \\ \Psi^{(t+1)} &= \text{diag} \left[\mathbf{S} - \mathbf{W}^{(t+1)} (\mathbf{A}^{(t)})^\top \right]. \end{aligned} \quad (5.73)$$

这里 diag 只保留对角元。将载荷的正规方程代入期望残差协方差, 即得噪声更新, 实际只需 $\mathbf{S}$ 的对角。不能省略二阶矩中的 $\mathbf{V}^{(t)}$, 否则低估噪声。PPCA 也可用 EM, 将各维期望残差方差取平均即可。

用 PPCA 载荷和正的对角残差初始化, 重复两步; 对角逆用除法, 其余逆用线性求解。可预设 $\psi_j \geq \varepsilon > 0$, 将更新截在下界, 但须说明这是受约束估计。停止时检查相对残差

$$\begin{aligned} r_\ell^{(t)} &= \frac{|\ell^{(t+1)} - \ell^{(t)}|}{1 + |\ell^{(t)}|}, \\ r_C^{(t)} &= \frac{\|\mathbf{C}^{(t+1)} - \mathbf{C}^{(t)}\|_F}{1 + \|\mathbf{C}^{(t)}\|_F}. \end{aligned} \quad (5.74)$$

两者连续若干步低于阈值时停止, 并设最大迭代数。协方差残差不受载荷旋转影响; 达到迭代上限不等于收敛。

5.4.1.3 理论分析

收敛性分析 PPCA 谱解直接给出条件下的全局最优。FA 的精确 EM 提高当前似然的相切下界, 故似然不下降, 有上界时其数值收敛。参数收敛到驻点还需连续性、迭代有界等条件, 不保证全局最优。弱因子或近零独特方差可能使 EM 很慢。

泛化分析 先在消除载荷旋转后的局部可识别坐标 θ 中讨论信息量。令 $\mathbf{s}_\theta(\mathbf{x}) = \nabla_\theta \log p_\theta(\mathbf{x})$ 。若密度的支撑集不随参数变化 (更一般地, 相应边界项为零), p_θ 在真参数邻域内二阶可微, 并有可积包络控制一、二阶导

数, 使微分与积分交换合法, 则得分期望为零, 且

$$\mathbf{I}(\theta) = \mathbb{E}_{\theta}[\mathbf{s}_{\theta}(\mathbf{X})\mathbf{s}_{\theta}(\mathbf{X})^{\top}] = -\mathbb{E}_{\theta}[\nabla_{\theta}^2 \log p_{\theta}(\mathbf{X})].$$

这才是得分外积与期望负 Hessian 相等的 Fisher 信息恒等式, 而不是对所有参数化模型都无条件成立的定义⁶⁹。

最大似然估计的一致性还要求真参数是总体期望对数似然的唯一最大点, 并有一致大数律及紧性或强制性条件把样本最大点限制在其邻域。渐进正态性则进一步要求真参数是内点, 模型在该点二次均值可微, Fisher 信息非奇异, 局部对数似然满足平方可积的 Lipschitz 控制, 并且所选最大似然估计一致。在样本独立同分布、模型正确且 d, k 固定的这些条件下,

$$\sqrt{n}(\hat{\theta}_n - \theta_0) \xrightarrow{d} \mathcal{N}(\mathbf{0}, \mathbf{I}(\theta_0)^{-1}).$$

这些条件及其标准形式可参见 van der Vaart 关于 M 估计和光滑参数模型的论述⁷⁰。原始载荷因旋转不识别而不趋于唯一矩阵。FA 还须区分低秩信号与对角噪声; 参数数目不超过 $d(d+1)/2$ 只是必要条件, 须另查约束后的局部一一对应性与导数满秩。秩退化、零噪声和维数随样本增长均需另作分析。

训练似然偏向较大的 k , 需要惩罚复杂度。常规模型可比较赤池信息准则 AIC 和贝叶斯信息准则 BIC:

$$\text{AIC} = -2\hat{\ell} + 2p, \quad \text{BIC} = -2\hat{\ell} + p \log n,$$

其中 p 包括均值和可识别协方差参数, 准则越小越好。奇异点不能直接套用该惩罚, 可考虑适当的证据近似或留出验证。普通 PCA 也可交叉验证重构误差。潜变量维数 k 取决于噪声假设和任务, 不自动等于内在维数 m 。

若样本 i 只观测到坐标集 O_i , 线性模型直接使用子向量的边际分布

$$\mathbf{x}_{i,O_i} \sim \mathcal{N}(\boldsymbol{\mu}_{O_i}, \mathbf{C}_{O_i,O_i}). \quad (5.75)$$

训练目标是各样本边缘对数似然之和。E 步用 $\mathbf{W}_{O_i,\cdot}$ 和 $\boldsymbol{\Psi}_{O_i,O_i}$ 求后验, 后验协方差因观测模式不同而变化。M 步按各维实际观测更新, 或将缺失值与潜变量一起视为未观测量, 计算所需的一、二阶矩, 不能照搬无缺失观测时的更新。补全时用高斯条件均值预测缺失属性, 保留条件协方差或条件采样以传播不确定性; 只填均值再当成真实观测会低估误差。

忽略缺失机制通常要求**随机缺失** (missing at random, MAR): 给定已观测值后, 缺失概率不再依赖未观测值, 且缺失机制参数与数据模型参数相互独立取值。若未记录指标越严重越容易缺失, 观测边缘似然未必消除偏差, 需另建缺失机制模型⁷¹。

⁶⁹ A. W. van der Vaart, *Asymptotic Statistics*, Cambridge University Press, 1998

⁷⁰ A. W. van der Vaart, *Asymptotic Statistics*, Cambridge University Press, 1998

⁷¹ D. B. Rubin, *Inference and Missing Data* In *Biometrika*, 1976, vol. 63, no. 3, pp. 581–592

PCA 也有补全扩展, 概率模型的特点是统一补全、表示和似然。多个局部线性结构还能组合为混合 PPCA, 须另查识别与退化问题。

5.4.1.4 小结

PPCA 连接主子空间与最大似然, FA 允许异质噪声, 适用于心理测量、经济计量或市场调研中的共同因子建模。两者都提供条件于参数的后验和生成过程, 但 PPCA 坐标不等于原样 PCA 得分, FA 方向也不必是主成分。

5.4.2 高斯过程潜变量模型 (GPLVM)

少量状态控制的姿态或运动也可能形成弯曲结构。**高斯过程潜变量模型** (Gaussian process latent variable model, GPLVM) 给低维到高维的映射设置函数先验, 再从观测寻找未知输入坐标。第2.4.1节的高斯过程回归从已观测输入预测响应, GPLVM 则把这些输入坐标也作为未知潜变量; 两者复用核协方差和边缘似然计算, 但任务方向不同。

Lawrence 在 2003 年提出 GPLVM, 并于 2005 年系统阐述了这一模型⁷²。这项工作从概率 PCA 的对偶表述出发: 改变被积分和被估计的对象, 将线性映射的载荷积分掉, 转而估计潜在坐标。随后用高斯过程描述这一映射, 便能引入非线性函数先验。这一推导路线也解释了为什么基本 GPLVM 虽然考虑了映射的不确定性, 潜在坐标本身仍可以是点估计。

⁷² N. D. Lawrence, *Probabilistic Non-linear Principal Component Analysis with Gaussian Process Latent Variable Models* In Journal of Machine Learning Research, 2005, vol. 6, no. 60, pp. 1783–1816

5.4.2.1 模型结构

高斯过程 (Gaussian process, GP) 规定任意有限组输入处的函数值共同服从高斯分布, 协方差核控制相关性和变化尺度。本小节的 $\mathbf{X}$ 已按训练均值中心化, 生成时加回均值; $\mathbf{Z} \in \mathbb{R}^{n \times k}$ 按行存储潜在坐标。模型为

$$\begin{aligned} f_j &\sim \mathcal{GP}(0, \kappa_\theta), \quad j = 1, \dots, d, \\ x_{i,j} &= f_j(\mathbf{z}_i) + \epsilon_{i,j}, \quad \epsilon_{i,j} \sim \mathcal{N}(0, \sigma^2). \end{aligned} \quad (5.76)$$

各函数独立、共享核参数 θ ; 噪声彼此独立且独立于函数。同一函数跨样本的值通过核相关。非参数性指不预先限制为固定有限组基函数, 并非没有待学习参数。

固定 $\mathbf{Z}$, 把函数值积分掉。令 $\mathbf{K}_{i,h} = \kappa_\theta(\mathbf{z}_i, \mathbf{z}_h)$, $\mathbf{C}_Z = \mathbf{K} + \sigma^2 \mathbf{I}_n$, 便有

$$\begin{aligned} p(\mathbf{X} | \mathbf{Z}) &= \prod_{j=1}^d \mathcal{N}(\mathbf{X}_{:,j}; \mathbf{0}, \mathbf{C}_Z), \\ \ell &= -\frac{nd}{2} \log(2\pi) - \frac{d}{2} \log |\mathbf{C}_Z| \\ &\quad - \frac{1}{2} \text{tr}(\mathbf{C}_Z^{-1} \mathbf{X} \mathbf{X}^\top). \end{aligned} \quad (5.77)$$

这里的协方差跨样本，是 n 阶而非 PPCA 的 d 阶矩阵。基本 GPLVM 优化 $\mathbf{Z}, \boldsymbol{\theta}, \sigma^2$ ，坐标仍是点估计。增加独立标准高斯坐标先验后，目标多出 $-\|\mathbf{Z}\|_F^2/2$ ；最大后验估计仍不保留坐标分布。

线性核 $\kappa(\mathbf{z}, \mathbf{z}') = \mathbf{z}^\top \mathbf{z}'$ 等价于标准高斯载荷的线性函数先验。积分载荷、优化坐标，得到 $\mathbf{C}_Z = \mathbf{Z}\mathbf{Z}^\top + \sigma^2 \mathbf{I}_n$ ，称为**对偶 PPCA**。它与 PPCA 交换被积分和被优化的对象，不是相同的联合概率模型。

对 $\mathbf{G} = \mathbf{X}\mathbf{X}^\top/d$ 取谱，记有序特征值为 ρ_i 、前 k 个特征向量为 $\mathbf{V}_k$ ， $\mathbf{D}_k = \text{diag}(\rho_1, \dots, \rho_k)$ 。无坐标先验惩罚时，若 $k < n$ 、 $\eta = (n-k)^{-1} \sum_{i>k} \rho_i > 0$ 且 $\rho_k > \eta$ ，同一谱证明给出

$$\begin{aligned} \hat{\sigma}_{\text{dual}}^2 &= \eta, \\ \hat{\mathbf{Z}} &= \mathbf{V}_k(\mathbf{D}_k - \eta \mathbf{I}_k)^{1/2} \mathbf{R}. \end{aligned} \quad (5.78)$$

归一化是除以 d ，不是 PPCA 中的 n 。左右奇异向量使两者联系到 PCA，但缩放、噪声估计和条件分布不同；加入坐标先验后此谱解不再直接成立。

平方指数或 Matérn 核允许非线性生成，也限制其平滑程度，不保证恢复任意映射。核 PCA 的核在已知观测上计算，这里的核在未知潜在坐标上计算，两者并非同一种核化。

5.4.2.2 参数学习

目标对 $\mathbf{Z}$ 非凸，可用 PCA 初始化，再用 L-BFGS、共轭梯度等最小化负对数似然，多次初始化并留出验证。某些核还存在平移、旋转或坐标尺度与长度尺度的补偿对称性，不能把一次优化结果当作唯一全局解。

对行列式和逆矩阵求微分，得到协方差梯度及链式法则：

$$\begin{aligned} \mathbf{H} &:= \frac{\partial \ell}{\partial \mathbf{C}_Z} \\ &= \frac{1}{2} \mathbf{C}_Z^{-1} \mathbf{X}\mathbf{X}^\top \mathbf{C}_Z^{-1} - \frac{d}{2} \mathbf{C}_Z^{-1}, \\ \frac{\partial \ell}{\partial a} &= \text{tr} \left(\mathbf{H}^\top \frac{\partial \mathbf{C}_Z}{\partial a} \right). \end{aligned} \quad (5.79)$$

标量 a 可为坐标、核超参数或噪声方差，后一式把似然梯度传到这些未知量。

带自动相关性确定 (automatic relevance determination, ARD) 的核为每个潜在坐标学习独立长度尺度。记逆长度尺度平方为 α_r ，它控制该维差异对函数相关性的影响。坐标影响核矩阵对应的行和列，链式求导时两处均需计入；正参数以对数参数化优化。

实现不显式求逆，而做 Cholesky 分解 $\mathbf{C}_Z = \mathbf{L}\mathbf{L}^\top$ ，以 $2 \sum_i \log L_{i,i}$ 算对数行列式，通过三角求解计算逆矩阵作用。必要的数值抖动与统计噪声应分

开记录。

稠密分解需 $O(n^3)$ 时间、 $O(n^2)$ 存储, 可承受规模依赖硬件与迭代数。稀疏 GPLVM 用 $b \ll n$ 个**诱导点**, 以少量可学习位置的函数值概括函数信息, 核心矩阵成本降为 $O(nb^2 + b^3)$, 另有输出与核计算成本及近似误差⁷³。

给定潜在坐标, GP 条件分布提供生成观测的均值和方差; 后者包含函数不确定性及观测噪声, 不是潜在坐标的位置方差。给定新观测要求编码时, 输入坐标未知, 必须反求

$$\hat{\mathbf{z}}_* = \arg \max_{\mathbf{z}} \{\log p(\mathbf{x}_* | \mathbf{z}, \mathbf{X}, \mathbf{Z}) + \log p(\mathbf{z})\}, \quad (5.80)$$

无先验版本去掉先验项。反问题可能多解, 需初始化或进一步近似坐标后验; GP 正向预测不是直接编码器, 额外的反向映射属于扩展。

若输出 j 只在索引集 I_j 处被观测, 使用 $\mathcal{N}(\mathbf{X}_{I_j, j}; \mathbf{0}, (\mathbf{C}_Z)_{I_j, I_j})$ 。不同缺失模式不能共用一次完整分解; 给定坐标可预测缺失输出, 但仍未传播坐标不确定性, 且需前述缺失可忽略条件。

Titsias 与 Lawrence 于 2010 年提出**贝叶斯 GPLVM**⁷⁴。这一方法用变分分布近似坐标后验, 优化不超过对数边缘似然的**证据下界** (evidence lower bound, ELBO):

$$\begin{aligned} q(\mathbf{Z}) &= \prod_i \mathcal{N}(\mathbf{z}_i; \mathbf{v}_i, \mathbf{S}_i), \\ \log p(\mathbf{X}) &\geq \mathcal{L}, \\ \mathcal{L} &= \mathbb{E}_{q(\mathbf{Z})}[\log p(\mathbf{X} | \mathbf{Z})] \\ &\quad - \text{KL}(q(\mathbf{Z}) \| p(\mathbf{Z})). \end{aligned} \quad (5.81)$$

均值 $\mathbf{v}_i$ 和正定协方差 $\mathbf{S}_i$ 是变分参数, KL 为 Kullback-Leibler 散度。将边缘似然写成 q 下的期望, 再用 Jensen 不等式将对数移入期望便得此式: 第一项拟合数据, 第二项惩罚偏离先验。等价地,

$$\log p(\mathbf{X}) - \mathcal{L} = \text{KL}(q(\mathbf{Z}) \| p(\mathbf{Z} | \mathbf{X})) \geq 0.$$

因此“下界”指 $\mathcal{L}$ 不超过对数边缘似然; 只有近似后验 $q(\mathbf{Z})$ 与真实后验一致时, 这个差距才为零。

第一项涉及随机核矩阵的逆与行列式, 仍难直接积分。原方法引入诱导函数值进一步下界化, 使高斯变分分布与适当核的所需期望可解析计算。诱导点位置通常作为变分参数优化, 核超参数与噪声也通常点估计, 并非所有未知量都做了全贝叶斯积分。

ARD 权重 α_r 小时, 核不敏感于该维差异。这是相关性学习, 有助于筛选有效方向, 但依赖先验、尺度、噪声与优化, 不保证恢复真维数。变分正则也不消除所有过拟合, 应检验留出预测与不确定性校准。

⁷³ N. D. Lawrence, *Learning for Larger Datasets with the Gaussian Process Latent Variable Model* In Proceedings of the Eleventh International Conference on Artificial Intelligence and Statistics, 2007, pp. 243–250

⁷⁴ M. K. Titsias, N. D. Lawrence, *Bayesian Gaussian Process Latent Variable Model* In Proceedings of the Thirteenth International Conference on Artificial Intelligence and Statistics, 2010, pp. 844–851

5.4.2.3 小结

GPLVM 从观测反求函数输入，基本版本给出坐标点估计和条件函数预测，贝叶斯版本近似坐标后验。人体姿态、机器人运动、蛋白质构象还可能需领域先验；核成本、局部最优和反向编码限制其使用。

5.4.3 模型对比与总结

表 5.4 从生成、学习与使用比较三种模型。噪声结构、映射形式和是否保留潜变量后验是不同的选择，不能相互替代。

比较方面	PPCA	FA	GPLVM
生成映射	线性，共享各向同性噪声	线性，各观测坐标独立噪声	GP 函数先验；非线性取决于核，基本噪声为同方差高斯
学习方法	正噪声非退化情形有谱解；也可 EM	通常用 EM 或其他数值优化	优化坐标和超参数；贝叶斯版本优化变分下界
潜变量不确定性	给定参数时有精确高斯后验	给定参数时有精确高斯后验	基本版本为坐标点估计；需后验近似才能量化位置不确定性
新观测编码	一次线性变换	一次线性变换	通常需反求新坐标，GP 正向预测本身不是编码
缺失观测	观测子协方差边际化	观测子协方差边际化	按输出的观测索引选取核子矩阵
主要用途	线性压缩、去噪、受约束协方差估计	异质测量误差、共同因子建模	非线性生成关系、给定潜变量的输出预测

表 5.4 概率降维模型比较。后验以固定参数为条件；GPLVM 的函数预测方差不是潜在坐标方差。缺失值处理均要求正确边际化及可忽略的缺失机制。

完整稠密数据下，PPCA 形成协方差并完整分解需 $O(nd^2 + d^3)$ ，截断 SVD 或 EM 会改变成本。FA 利用对角噪声，每步 EM 约需 $O(ndk + nk^2 + dk^2 + k^3)$ ，总成本再乘迭代数 T 。稠密 GPLVM 每步通常需 $O(n^3 + n^2d + n^2k)$ 。比较必须固定求解器及 n, d, k ，不能只看模型名称。

多个局部线性结构可用**混合 PPCA**（mixture of PPCA）建模：以非负且和为 1 的权重混合多个 PPCA 密度⁷⁵。它与第 4.6.1 节的高斯混合模型都引入潜在成分变量和责任度，但每个成分在这里还包含低秩信号与噪声结构。EM 同时学习责任度和局部载荷，结合软聚类与局部降维；局部坐标却不自动构成连续的全局嵌入，还须控制分量坍塌与噪声趋零。

为控制维数，**贝叶斯 PPCA** 给载荷列加分层先验，如 $\mathbf{W}_{:,r} \mid \beta_r \sim \mathcal{N}(\mathbf{0}, \beta_r^{-1} \mathbf{I}_d)$ 。大 β_r 压缩对应载荷，以 ARD 选择有效复杂度；它不保证找到真维数，算法也可采用证据最大化而非全参数积分⁷⁶。

计数或二值数据需要合适的观测分布。**指数族 PCA** 对自然参数施加低秩结构，用条件似然替换平方误差。泊松、伯努利分别对应计数与二值；正连续数据可考虑满足参数域约束的 Gamma 观测，而非正态-Gamma 共轭先验。Collins、Dasgupta 与 Schapire 的推广并不自动包含潜变量先验，

⁷⁵ M. E. Tipping, C. M. Bishop, *Mixtures of Probabilistic Principal Component Analyzers* In *Neural Computation*, 1999, vol. 11, no. 2, pp. 443–482

⁷⁶ C. M. Bishop, *Bayesian PCA* In *Advances in Neural Information Processing Systems*, 1999, pp. 382–388

仍须区分低秩分解与完整生成模型⁷⁷。

复杂生成关系还可利用**变分自编码器** (variational autoencoder, VAE): 网络参数化观测条件分布, 并由共享编码器输出近似后验, 这称为摊销变分推断。高斯后验以“均值加标准差逐元素乘标准高斯噪声”重参数化, 使随机采样可用于下界梯度估计。VAE 因此不只是把 GP 换成神经网络, 还改变推断与训练方法; 第7.1节提供神经表示学习入口, 网络结构和训练由神经网络模型部分展开⁷⁸。

概率降维以生成假设解释误差、支持推断和缺失值处理, 收益取决于假设是否合适、保留了哪些不确定性。线性结构可从 PPCA 或 FA 入手, 非线性函数先验可考虑 GPLVM; 数据机制、预测目标和计算预算共同决定选择。

⁷⁷ M. Collins, S. Dasgupta, R. E. Schapire, *A Generalization of Principal Components Analysis to the Exponential Family* In *Advances in Neural Information Processing Systems*, 2001, pp. 617–624

⁷⁸ D. P. Kingma, M. Welling, *Auto-Encoding Variational Bayes* In arXiv preprint arXiv:1312.6114, 2013

5.5 模型选择与评价

5.5.1 方法比较

按用途选择候选的起点见表5.5, 再用表5.6核对映射、假设与样本外机制。

分析需求	可比较的方法	应检查的关键条件
压缩、去相关与重构	PCA、稀疏 PCA	尺度、解释方差、载荷稳定性
分离低秩背景与污染	RPCA 及稳定变体	污染的稀疏形式、可识别性
非负成分的加性解释	NMF	非负性含义、损失与成分稳定性
少量原子的灵活组合	稀疏编码、字典学习	活跃原子数、推断成本
流式与超高维预处理	随机投影	有限点集的距离失真与输出维数
两个配对视图的共有信息	CCA 及正则化变体	配对质量、留出相关性
线性混合信号的分离	ICA	源独立性、源数与噪声
响应或类别相关的表示	PLS、LDA、SIR	监督信息仅在训练折使用, 下游风险相对无监督与不降维基线
只有距离或序数差异	经典、度量或非度量 MDS	距离可嵌入性、应力目标
弯曲结构与几何分析	核 PCA、Isomap、LLE、拉普拉斯特征映射	核、邻域、连通性与几何失真
连通结构的多尺度分析	扩散映射	密度归一化、扩散时间与谱截断
探索高维邻域结构	t-SNE、UMAP	邻域参数、初始化与重复运行
缺失观测、噪声与生成建模	PPCA、FA、GPLVM	观测模型、缺失机制与后验近似

表 5.5 按保留目标选择降维方法的起点。结果还应结合重构、邻域保持、样本外任务或预测分布评价; 不同目标之间通常存在取舍。

表5.6比较各方法保留什么、怎样处理新样本, 以及依赖哪些条件。核 PCA 归在线性关系的特征空间扩展中, MDS 单列距离方法; 几何展开与可视化布局都归入邻域方法, 但保留对象仍须分别比较。

随机投影一行中的“固定有限点集”限定的是随机映射的保证范围, 而不是对点集来源施加概率分布假设: 点集可以任意, 但必须在抽取映射前固定。核 PCA 的核正定性则是核能否表示特征内积的合法性条件, 不是

代表方法	映射形式	保留对象	数据假设	样本外机制	下游用途
PCA、CCA、ICA；随机投影	前三者从数据学习线性投影或解混；随机投影与数据独立抽取	方差、跨视图相关、独立源或欧氏距离	前三者分别假设低秩线性结构、配对视图或独立混合；随机投影无数数据分布假设，JL 保证只覆盖映射抽取前固定的有限点集	共享矩阵直接变换	压缩、去噪、多视图对齐、信号分离或高维预处理
NMF、稀疏编码 经典 MDS；核 PCA	线性生成字典；逐样本约束推断 MDS 由差异矩阵恢复谱坐标；核 PCA 由合法正定核定义特征空间谱坐标	非负加性重构或稀疏支持 MDS 保留双中心内积及诱导距离；核 PCA 保留特征空间方差	非负观测或少量活跃原子 MDS 要求差异同尺度，欧氏差异对应半正定 Gram 矩阵；核 PCA 另要求核诱导几何适合任务	固定字典后重新求系数 MDS 扩展到训练点的差异；核 PCA 按训练中心化规则作核投影	部件解释、去噪与信号表示 关系数据表示、非线性预处理与几何诊断
Isomap、LLE、拉普拉斯特征映射、扩散映射	由训练图求非参数坐标	测地距离、局部重构、图平滑或扩散距离	可信邻域、充分采样及相应流形或图结构	接入训练图后插值、距离扩展或谱延拓	几何分析、多尺度连通性与后续建模
SNE、t-SNE、UMAP	由邻域关系优化训练布局	条件邻居概率、点对概率或模糊边权	输入距离能表达局部相似性	原始形式无共享函数；可作参考图变换或另学参数映射	低维探索、局部结构展示与假设生成
PPCA、FA、GPLVM	潜变量到观测的线性或核生成映射	低秩协方差、异质噪声或非线性生成关系	指定观测分布、噪声结构与核先验	后验线性编码，或对新观测反求潜在坐标	去噪、缺失值处理、生成建模与不确定性推断

表 5.6 降维方法的属性导航。各行给出本章标准形式的主要属性，而非互斥类别；具体变体可以改变映射、假设和样本外机制。

任务几何假设；即使核合法，仍须用验证数据判断它诱导的相似关系是否适合当前用途。

5.5.2 评价与选择

高维分析的困难也不只是无法画图。**维数灾难**（curse of dimensionality）指维数增长使空间覆盖与统计估计变得困难的一组现象。例如，在每个坐标上把单位区间分为十段， d 维空间就有 10^d 个小区域；有限样本很快不足以覆盖这些区域。在一些具有许多弱相关分量的分布中，距离还会集中，使最近与最远样本的相对差异变小。这些现象依赖分布和度量，不能理解为所有高维数据中的距离都没有意义。降维只有在冗余、低维结构或任务相关信息确实存在时，才有机会缓解它们。

内在维数 m 描述给定尺度、噪声和结构假设下的局部自由度；表示维数 k 是根据用途选择的输出规模。可视化另用 $k_{\text{vis}} \in \{2, 3\}$ ，它只反映显示限制，不能证明 m 也等于 2 或 3，也不能代替下游用途所需的 k 。

降维是否成功必须按用途评价。数据划分先于指标选择：所有由数据估

计的均值、尺度、特征选择、投影、字典、核参数和邻域图都只在训练折内拟合；验证数据用于选择方法、表示维数 k 和其他超参数；选择规则冻结后，最终测试数据才用于报告样本外结果。没有共享样本外机制的训练布局只能支持固定样本上的探索，若要声称可用于新样本，就必须预先规定参考图扩展、插值或参数映射。表5.7把重构、距离、邻域、可视化、下游任务、稳定性和参数敏感性分开，并要求与同一 k 和同一预算下的简单基线比较。

邻域评价需要区分两种失真：低维中新增了原本不近的邻居，或丢失了原本相近的邻居。固定同一批 n 个评价对象及两空间的距离，令 $N_i^X(q)$ 、 $N_i^Z(q)$ 分别为原空间和低维空间中样本 i 的 q 个近邻索引集，均排除 i 本身；距离平局按预定的固定规则打破。平均近邻重合率为

$$\frac{1}{nq} \sum_{i=1}^n |N_i^X(q) \cap N_i^Z(q)|.$$

它只数保留了多少邻居。**信任度** (trustworthiness) 进一步惩罚低维新增的错误近邻，**连续性** (continuity) 惩罚丢失的原空间近邻；两者都按相应空间中的距离秩衡量错误有多大，这里的连续性不是映射的拓扑连续性。

记 $r_{i,j}$ 、 $s_{i,j}$ 分别为 j 在 i 的原空间和低维距离排序中的秩，最近者为 1，最远者为 $n-1$ 。新增与丢失的近邻集合分别为

$$U_i = N_i^Z(q) \setminus N_i^X(q), \quad V_i = N_i^X(q) \setminus N_i^Z(q).$$

对整数 $1 \leq q < n/2$ ，常用归一化定义为

$$\begin{aligned} T(q) &= 1 - \frac{2}{nq(2n-3q-1)} \sum_{i=1}^n \sum_{j \in U_i} (r_{i,j} - q), \\ C(q) &= 1 - \frac{2}{nq(2n-3q-1)} \sum_{i=1}^n \sum_{j \in V_i} (s_{i,j} - q). \end{aligned} \quad (5.82)$$

其中 $T(q)$ 为信任度， $C(q)$ 为连续性。此范围内，单个对象的最大秩罚分为最远 q 个秩超出 q 的总和 $q(2n-3q-1)/2$ ，故两项指标均落在 $[0, 1]$ ，越大表示相应失真越少。它们仍只评价所选距离与邻居数下的邻域保持，不证明语义正确或样本外可靠。

选择维数时，可以按同一数据协议依次缩小候选范围：

1. 先声明下游用途和保留对象，并据此确定重构、距离、邻域、可视化或任务风险中的主要证据。
2. 在训练折内完成尺度与表示拟合，再用局部谱、邻域尺度、重构曲线或内在维数估计形成 m 与候选 k 的证据；这些估计依赖尺度和假设，不作为真值标签。

证据	测量与数据用法	基线或对照	不能单独替代
重构与压缩	在验证或测试样本上报告与观测类型匹配的重构损失，并同时计算表示、模型或字典存储及编码、解码成本	均值重构、同一 k 的 PCA，以及不压缩的原始输入	距离、判别信息或语义解释
距离保持	对预先声明的点对报告相对失真、应力或秩相关；样本外主张须在训练映射未见过的数据上计算	同一 k 的 PCA 或随机投影及原始距离	邻域保持、可视化可信或下游风险
邻域保持	在固定输入度量与邻居数下报告近邻重合率、信任度或连续性，并检查不同局部尺度	原始空间邻域、同一 k 的 PCA 或随机布局	全局距离、真实簇数或因果关系
可视化	固定 $k_{\text{vis}} = 2$ 或 3，结合距离或邻域诊断、多次初始化和领域标注说明图上哪些关系可读	二维或三维 PCA、随机标签或与任务匹配的简单投影	高维结构存在、簇语义正确或最佳预测表示
下游任务	把降维器放入每个训练折，与后续回归、分类或聚类共同选择，在独立测试集报告相应风险或效用	同一学习器使用原始表示、简单 PCA 和任务允许的特征选择	几何保真、生成假设正确或解释可靠
稳定性	改变样本、初始化和随机种子；对齐坐标后比较子空间，或直接比较距离、邻域和下游结论等不变量	算法自身多次运行及确定性基线	统计正确性；稳定的偏差仍可能重复出现
参数敏感性	在预先给定范围内改变 k 、邻居数、核带宽、困惑度或正则强度，报告结论在哪些范围保持	默认参数、简单尺度规则和等预算搜索	独立测试；用测试集挑参数会使其失去最终证据资格

表 5.7 降维的统一评价协议。各类证据回答不同问题；训练目标低、二维图清晰或单次下游得分高，都不能替代其余证据。

- 在验证数据上连同核、邻居数和正则强度选择 k 。若交付二维或三维图，则另设 k_{vis} ，并用较高维候选和表5.7中的诊断检查显示造成的额外失真。
- 冻结预处理、映射、 k 、样本外机制和评价规则，最后只在独立测试数据上报告结果；看过最终测试结果后再改维数，就需要新的测试证据。

实际流程可以先用 PCA 或随机投影压缩，再作非线性嵌入，但应验证前一步没有丢掉所需结构，“保留 50 维”只是经验起点。用于第2章或第3章的预测时，降维器、维数和后续模型必须在同一训练流程内选择，并在独立数据上比较风险；用于第4章的分组时，还须在原特征或经过验证的表示空间中检查稳定性、外部证据与下游用途，不能仅凭二维图判断。二维展示另用 k_{vis} ，不应迫使部署表示也取二维。

5.6 本章小结

降维要回答“用更少的坐标保留什么”。线性关系与核扩展分别在原空间或特征空间提取全局变化，距离方法恢复对象关系，邻域方法保留局部几何或布局，概率方法解释潜变量生成。方差、距离、邻域、重构和预测收益是不同目标，不能只凭维数变小判断成功。

内在维数 m 、表示维数 k 与可视化维数 k_{vis} 也不能互相替代。方法选择还取决于新样本怎样编码、哪些未知量保留不确定性，以及存储和计算成本。二维图可以提出假设，无法独立证明高维簇结构或最佳预测表示。

用于回归和分类时，降维须与预测模型在同一训练与验证流程中选择，并用独立数据评价风险；用于聚类时，则要同时检验表示所改变的距离与群组证据。只有与用途匹配、由相应证据支持的结构，才是低维表示确实保留的信息。

集成学习

在同一批信用风险数据上，两棵决策树可能因为训练样本稍有变化而形成不同的分支；一个线性模型与一棵树则可能分别抓住全局趋势和局部交互。面对这些差异，只从中选出一个模型，会丢掉其他模型已经学到的信息。能否让多个模型共同预测，并使组合在新样本上比单个成员更可靠？

集成学习（ensemble learning）研究的正是成员怎样产生、怎样相互依赖，以及怎样把它们的输出组合起来。

组合并不自动带来收益。若成员反复犯相同的错误，增加数量只会重复同一判断；若成员彼此不同却普遍不准确，分歧本身也不能改善预测。有效的集成必须同时处理成员质量、错误依赖与组合规则。本章先建立这套共同分析框架，再分别讨论三类主要机制：**Bagging** 通过训练扰动产生可并行的成员，**Boosting** 让后续成员序贯修正当前组合，**Stacking** 则从样本外预测中学习组合规则。

本章以监督预测为主要范围。组合后的回归响应、分类标签、得分和概率分别沿用第2章与第3章的任务语义；共识聚类见第4.7节，弱学习与投票风险的证明见第二卷“基础、理论和可信性”的“二分类学习的可学习性”章“集成学习”节。这里集中回答模型层的问题，不把成员数量、训练目标下降或某个软件实现的工程优势直接当作泛化保证。

6.1 集成学习概述

6.1.1 从单个模型到组合预测

第2.3节和第3.3节已经说明，树的分裂由有限训练样本决定。某些候选分裂的得分很接近时，替换少量样本就可能改变根节点，后续分支也随之变化。单棵树因而可能具有较大的训练波动。另一方面，一个受限的线性模型即使训练稳定，也可能无法表示风险只在局部条件组合下升高的现象。前一种困难主要来自估计不稳定，后一种困难主要来自表示受限；反复调节同一个模型的复杂度，不一定能同时消除二者。

集成学习在原有预测任务之外增加两个环节：先产生多个**成员模型**

(member model)，再组合这些成员的输出。强调训练方法或模型族时，也常把产生成员的算法称为**基学习器** (base learner)。成员可以是同一算法在不同样本或随机种子下的结果，也可以来自不同模型族；最终组合得到的对象称为**集成模型** (ensemble model)。这种做法没有改变响应或类别标签的含义，只改变了由训练数据形成预测器的路径。

组合方法围绕三个问题逐渐分化。Bagging 从训练集重采样多个成员并固定聚合规则，使易受数据扰动影响的预测更稳定；Boosting 让下一轮成员依赖当前组合，把新增容量分配给尚未处理好的训练信号；Stacking 则用样本外成员预测训练另一层模型，使组合规则也可以学习。

图6.1固定同一训练任务，比较三类方法改变的环节。Bagging 中的成员可以彼此独立训练；Boosting 的第 t 个成员依赖前 $t - 1$ 轮形成的当前预测；Stacking 的基成员可以独立训练，但组合层必须看到不含当前样本训练信息的折外预测。这些差异比“用了多少个模型”更能说明训练成本与泄漏风险。




图 6.1 Bagging、Boosting 与 Stacking 的成员生成及组合关系。实线表示训练或预测的主路径，虚线表示由前一轮组合产生的修正信号。三类方法都输出组合预测，但成员间依赖与组合规则不同；图中流程为机制示意，不表示三者必须使用相同成员模型。

6.1.2 成员、组合规则与输出

设训练集为

$$D_n = \{(\mathbf{x}_i, y_i)\}_{i=1}^n,$$

学习过程产生 M 个成员模型 $h_1, \dots, h_M$ 。用 $\mathcal{C}$ 表示组合规则，集成预测统一写成

$$H(\mathbf{x}) = \mathcal{C}(h_1(\mathbf{x}), \dots, h_M(\mathbf{x})). \quad (6.1)$$

式(6.1)只规定组合接口, 还没有规定输出的语义。回归成员若都预测同一个数值目标, 可以采用等权平均

$$H(\mathbf{x}) = \frac{1}{M} \sum_{m=1}^M h_m(\mathbf{x}),$$

也可以用非负权重 w_m 作加权平均, 其中 $\sum_m w_m = 1$ 。分类成员则可能输出硬标签、类别得分或类别概率。硬标签适合投票, 得分和概率可以逐类平均后再决策, 但三种量不能在没有任何转换的情况下混合。

输出类型之所以重要, 是因为相同的代数操作可能对应不同结论。两个分类器的得分尺度不同, 直接平均会让数值范围较大的成员取得更大影响; 两个成员都输出概率, 也不意味着平均后已经校准。若元学习器把成员得分映射为概率, 还要单独检查这个映射在新样本上的可靠性。第3.7节给出的硬标签、排序得分和类别概率评价接口同样适用于集成模型。

组合权重也不是成员的固有属性。等权平均预先固定权重, AdaBoost 在序贯训练中同时确定成员贡献, 线性 Stacking 则根据折外预测估计权重。权重还可以依赖输入, 此时 $w_m = w_m(\mathbf{x})$, 不同样本会调用不同成员或采用不同组合比例。成员数量、权重约束、组合层复杂度以及是否允许输入相关组合, 都属于训练或验证流程需要确定的模型选择。

6.1.3 成员质量、错误依赖与多样性

平均为什么可能比单个成员稳定, 可以先看一个受控情形。固定输入 $\mathbf{x}$, 把训练集抽取、重采样和训练随机性都视为随机来源。若 M 个成员预测具有相同方差 $\sigma^2(\mathbf{x})$, 任意两个不同成员的预测相关系数均为 $\rho(\mathbf{x})$, 则等权平均的方差为


$$\text{Var}[H(\mathbf{x})] = \sigma^2(\mathbf{x}) \left[\rho(\mathbf{x}) + \frac{1 - \rho(\mathbf{x})}{M} \right]. \quad (6.2)$$

其中随 M 衰减的是成员不共享的波动; $\rho(\mathbf{x})\sigma^2(\mathbf{x})$ 所代表的共同变化不会因继续增加同类成员而消失。式(6.2)依赖等方差、等相关的简化设定, 用来解释相关性的作用, 不是任意集成的精确风险公式。

图6.2把这一差别写成成员误差的两部分。成员特有波动 u_m 在平均中可能相互抵消; 若每个成员都带有共同误差 c , 增加同类成员只能继续削弱前一部分, 不能消除 c 。因此, 成员数增长与成员错误依赖下降是两个不同的条件。

平方误差还给出另一个逐点恒等式。对非负权重 w_m 且 $\sum_m w_m = 1$, 令

(a) 只有成员特有波动



(b) 成员还共享同一偏移




图 6.2 成员误差依赖与平均的作用。左图表示只有成员特有波动时，平均可以随成员数增加而削弱这些波动；右图表示所有成员还共享误差 c 时，共同项仍保留在平均预测中。图中成员数量与符号只用于说明机制，不表示实测误差。

$H(\mathbf{x}) = \sum_m w_m h_m(\mathbf{x})$, 则

$$(y - H(\mathbf{x}))^2 = \sum_{m=1}^M w_m (y - h_m(\mathbf{x}))^2 - \sum_{m=1}^M w_m (h_m(\mathbf{x}) - H(\mathbf{x}))^2. \quad (6.3)$$

右侧第一项是成员平方误差的加权平均，第二项衡量成员围绕组合预测的分散程度，常称为歧义项¹。在成员平均误差固定时，更大的有效分散会降低组合误差；但若为了制造分散而加入很差的成员，第一项也会增大。多样性只能与成员质量一起解释。

分类投票没有完全相同的平方误差分解，却面对同一问题：关键不只是每个成员错多少次，还包括它们是否在同一批样本上出错。对一对分类器，可以记录二者同时正确、只有一个正确和同时错误的样本数 $n_{1,1}, n_{1,0}, n_{0,1}, n_{0,0}$ 。分歧率 $(n_{1,0} + n_{0,1})/n$ 描述二者给出不同正确性结果的频率，双错率 $n_{0,0}/n$ 直接关注共同错误；Q 统计量

$$Q = \frac{n_{1,1}n_{0,0} - n_{1,0}n_{0,1}}{n_{1,1}n_{0,0} + n_{1,0}n_{0,1}}$$

在分母非零时描述两种正确性结果的关联。不同指标关注的对象不同，也不存在一个脱离成员准确率、对所有任务都能单调预测集成风险的多样性分数²。

成员差异可以从多个位置产生。改变训练样本会改变成员看到的经验分布；改变输入特征会改变可用信息；改变模型结构或超参数会改变表示与正则；改变初始化、样本顺序或分裂候选会改变优化路径。Bagging 主要扰动训练样本，随机森林和 Extra Trees 进一步扰动特征或阈值，Stacking 则允许直接组合不同模型族。这些机制只是多样性的来源，最终是否形成互补仍要用样本外预测检查。

¹ A. Krogh, J. Vedelsby, *Neural Network Ensembles, Cross Validation, and Active Learning* In *Advances in Neural Information Processing Systems*, 1995, pp. 231–238

² L. I. Kuncheva, C. J. Whitaker, *Measures of Diversity in Classifier Ensembles and Their Relationship with the Ensemble Accuracy* In *Machine Learning*, 2003, vol. 51, no. 2, pp. 181–207

由此可以用三个维度比较后续方法：成员怎样产生，成员之间有什么依赖，组合规则怎样确定。Bagging 采用扰动后的成员和固定聚合，Boosting 采用序贯依赖成员和加法组合，Stacking 采用样本外成员预测和学习式组合。三类方法都可能改善预测，也都可能因共同失配、数据泄漏或过度选择而失效。

6.2 基于 Bagging 的集成

若一个学习算法对训练样本的细小变化很敏感，可以在同一总体上设想反复取得训练集、反复训练模型，再平均预测。真实任务通常只有一份训练集，无法直接完成这种重复抽样。**装袋法** (bootstrap aggregating, Bagging) 用自助采样从现有训练集构造多份样本，分别训练成员，再用固定规则聚合。该方法主要减弱能够被重采样暴露出来的训练波动，不会自动修正所有成员共享的表示偏差³。

³ L. Breiman, *Bagging Predictors In Machine Learning*, 1996, vol. 24, no. 2, pp. 123–140

6.2.1 Bagging

6.2.1.1 自助样本与聚合预测

对第 m 个成员，从 $\{1, \dots, n\}$ 中独立、等概率、有放回地抽取 n 次索引，所得多重集合记为 $I^{(m)}$ 。同一原始样本可能出现多次，也可能一次都没有出现。学习算法 $\mathcal{A}$ 在相应自助样本上训练出

$$h_m = \mathcal{A}(D_n^{(m)}), \quad D_n^{(m)} = \{(\mathbf{x}_i, y_i) : i \in I^{(m)}\}.$$

回归通常平均 $h_m(\mathbf{x})$ ；分类可以投票，也可以在成员输出具有同一语义时平均逐类得分或概率。自助样本大小不必固定为 n ，成员算法也不必是树，但方法是否受益取决于重采样能否产生有用的预测差异。

一份大小为 n 的标准自助样本没有抽中原始样本 i 的概率为

$$\mathbb{P}(i \notin I^{(m)}) = \left(1 - \frac{1}{n}\right)^n \longrightarrow e^{-1}. \quad (6.4)$$

因此，每个成员平均约有 36.8% 的原始样本未参与其训练。这些样本构成该成员的**袋外样本** (out-of-bag sample, OOB sample)。反过来，对每个训练样本 i ，可以只收集没有使用它训练的成员预测。令

$$\mathcal{M}_i^{\text{OOB}} = \{m : i \notin I^{(m)}\},$$

当 $\mathcal{M}_i^{\text{OOB}}$ 非空时，回归的袋外预测可写为

$$\hat{y}_i^{\text{OOB}} = \frac{1}{|\mathcal{M}_i^{\text{OOB}}|} \sum_{m \in \mathcal{M}_i^{\text{OOB}}} h_m(\mathbf{x}_i), \quad (6.5)$$

分类则对同一成员集合投票或平均类别输出。图6.3强调了袋外预测的样本级条件：不同训练样本由不同成员子集预测，而不是另行训练一个统一的“OOB 模型”。




图 6.3 Bagging 训练与袋外预测。每个成员只使用其自助样本训练；对训练样本 x_i ，袋外预测只聚合未抽中 i 的成员。图中索引和成员集合仅用于说明数据流；有限成员下，各样本可用的袋外成员数并不相同。

6.2.1.2 成员数量与误差来源

Bagging 的成员可以独立训练，因而适合把成员分配到不同计算单元。并行性只缩短墙钟时间，不会消除总计算量：若单个成员的训练和预测成本分别为 C_{train} 与 C_{pred} ，朴素实现的总工作量仍约随 MC_{train} 和 MC_{pred} 增长。模型存储也通常随成员数量增加。

增加成员数主要减小有限次随机抽样造成的 Monte Carlo 波动。若成员由同一随机训练机制产生，等权平均会随 M 增加逼近该随机机制下的期望预测；它不会消除原训练集有限、模型族不合适或成员高度相关造成的误差。实践中可以观察袋外损失随成员数的变化，在曲线趋于稳定后停止增加成员，但这个停止规则也属于模型选择过程。

成员模型的复杂度与成员数量承担不同职责。较深的树通常更能拟合每份自助样本，也更容易因样本扰动产生不同结构；平均可以削弱部分波动，却不意味着每棵树都应无条件生长到纯叶。叶最小样本量、最大深度、类别权重和自助样本大小仍须与成员数共同选择，尤其在标签噪声、极小叶或类别极不平衡时。

6.2.1.3 袋外预测的用途与边界

袋外预测没有使用当前样本训练相应成员，因而可用于观察成员数量、估计内部误差或构造置换重要性。它省去了为每个成员另设验证集的开销，

但与 K 折交叉验证并不相同：每个样本的袋外成员数随机变化，成员训练集之间也高度重叠。成员数很小时，某些样本可能没有足够的袋外预测。

如果模型结构、成员数和特征处理都反复根据袋外结果选择，最终袋外误差已经参与了选择，不再是冻结流程后的独立测试结果。时间序列、分组样本或空间相关数据还要求自助抽样尊重依赖单位；逐行重采样会破坏原有数据结构。袋外机制提供的是一种内部样本外预测来源，而不是脱离数据生成条件的无偏泛化保证。

6.2.2 随机森林

Bagging 若以树为成员，各棵树仍可能反复选择少数强特征，产生相近的上层分裂。**随机森林** (random forest) 在树的自助采样之外加入节点级特征随机化：每个节点先随机抽取一组候选特征，再只在这组特征中搜索分裂。树仍按第2.3节或第3.3节的任务准则形成叶输出，改变的是每个成员可参与分裂搜索的信息⁴。

候选特征数控制单树质量与树间依赖的取舍。候选数接近全部特征时，森林更接近普通的树 Bagging；候选数较小时，不同树更可能采用不同分裂，但单棵树也更容易错过当前节点上的有效特征。这一取舍还会受到特征冗余、样本量和树深影响，不能由一个固定默认值替代验证。

树数增加时，随机森林预测会逐渐稳定到其随机化机制对应的有限样本极限。这种稳定是对抽样随机性的收敛，不表示模型已经得到真实风险最小解，也不表示继续加树没有资源代价。随机森林的一致性结论通常针对特定的树构造、抽样比例与分布条件；实际软件在缺失值、类别特征、停止规则和并行实现上的差异，可能不满足同一组理论假设⁵。

6.2.2.1 特征重要性的解释

树集成常附带两类特征重要性。**不纯度下降重要性** (impurity-decrease importance) 累计某个特征参与分裂时带来的加权目标下降，计算方便，却可能偏向候选切分较多的特征。它还会把相关特征之间的可替代关系压缩进实际被选中的分裂，不能解释为变量的独立贡献。

置换重要性 (permutation importance) 固定已训练模型，在评价数据上打乱一个特征，再观察预测损失增加多少。这个量直接对应已拟合模型在所扰扰动下对该特征的依赖，但打乱会破坏该特征与其他特征的联合关系。高度相关的特征可能互相替代，使单个特征的置换影响看起来很小；不现实的特征组合也可能夸大损失变化。两类重要性都不是因果效应，需要连同评价数据、损失和置换方式一起报告⁶。

图6.4沿一棵树的构造路径比较三种随机化位置。树 Bagging 主要改变成员看到的训练样本；随机森林还在每个节点抽取候选特征；Extra Trees

⁴ L. Breiman, *Random Forests* In *Machine Learning*, 2001, vol. 45, no. 1, pp. 5–32

⁵ E. Scornet, G. Biau, J.-P. Vert, *Consistency of Random Forests* In *The Annals of Statistics*, 2015, vol. 43, no. 4, pp. 1716–1741

⁶ C. Strobl, A.-L. Boulesteix, A. Zeileis, T. Hothorn, *Bias in Random Forest Variable Importance Measures: Illustrations, Sources and a Solution* In *BMC Bioinformatics*, 2007, vol. 8, pp. 25

继续把随机性放入候选阈值。三者都保留树的任务准则，但交给贪心搜索的信息逐步受到更多约束。




图 6.4 树 Bagging、随机森林与 Extra Trees 的随机化位置。蓝色节点表示引入随机性的环节，红色节点表示仍按任务准则执行的搜索，黄色节点表示得到的成员树。每栏首框直接标出训练样本来源：前两栏采用自助采样，Extra Trees 栏采用原始方法的完整训练集设定；具体实现也可能额外启用自助采样。

6.2.3 极度随机树 (Extra Trees)

随机森林仍会在候选特征内搜索较优阈值。**极度随机树** (extremely randomized trees, Extra Trees) 把随机性进一步放入阈值选择：在每个节点，对随机选出的候选特征生成随机切分点，再从这些随机候选中选择得分较好的切分。原始方法通常让各棵树使用完整训练集，把成员差异主要交给特征与阈值随机化；具体软件也可能允许额外使用自助采样⁷。

随机阈值减少了穷举候选切分的工作，也会让单棵树偏离当前样本上的最佳贪心分裂。组合是否改善，取决于单树预测能力下降与成员依赖减弱之间的平衡。候选特征数、每个特征的随机阈值数、叶最小样本量以及是否采用自助采样共同决定这个平衡；“随机性更强”不能推出测试风险必然更低。

Extra Trees 还说明，Bagging 家族的共同点不是必须采用标准自助采样，而是通过受控扰动产生一组成员，并用固定规则聚合。随机子空间只扰动成员可见的特征，Pasting 以无放回子样本替代自助样本，随机权重则让同一记录在不同成员中具有不同影响。每种扩展都应明确扰动发生在哪里，以及它是否保留袋外预测等附带机制。

⁷ P. Geurts, D. Ernst, L. Wehenkel, *Extremely Randomized Trees In Machine Learning*, 2006, vol. 63, no. 1, pp. 3–42

6.2.4 模型对比与总结

表6.1固定树为成员，比较三种方法怎样产生差异。普通 Bagging 只改变训练样本；随机森林再限制节点可见的候选特征；Extra Trees 进一步随机化候选阈值。后两者并非简单地沿一条“随机性越多越好”的顺序排列，因为它们还可能采用不同抽样方案，并改变单树质量和搜索成本。

方法	样本扰动	节点候选特征	阈值选择	袋外预测	成员训练	主要边界
树 Bagging	通常自助采样	全部特征	在候选中搜索	标准自助设定下可用	成员间可并行	强特征可能使树高度相关
随机森林	通常自助采样	随机特征子集	在子集内搜索	标准自助设定下可用	成员间可并行	候选数过小会削弱单树
Extra Trees	原始方法使用完整训练集；实现可选自助采样	随机特征子集	生成随机阈值后择优	仅在采用自助采样时可用	成员间可并行	过强随机化会增大单树误差

表 6.1 以树为成员时，Bagging、随机森林与 Extra Trees 的机制比较。表中描述稳定的方法定义；软件默认值可能随实现和版本改变，实际比较还须固定树复杂度、成员数与计算预算。

Bagging 适合把训练扰动转化为成员差异，再通过聚合降低其中不共享的部分。若所有成员都遗漏同一结构，固定聚合不会主动告诉下一棵树应修正什么。下一节转向序贯成员：新成员不再独立产生，而是根据当前组合留下的训练信号继续更新。

6.3 基于 Boosting 的集成

Bagging 中的成员可以同时训练，因为一个成员不需要知道其他成员的预测。若希望新增成员专门补充当前组合尚未处理好的部分，这种独立性就不再成立。**Boosting**（提升）构造一个序贯加法模型：第 t 轮先观察已有函数 F_{t-1} ，再选择新成员及其贡献，使指定训练目标继续下降。AdaBoost、梯度提升及现代提升树共享这种依赖关系，但它们生成修正信号和近似目标的方式不同。

6.3.1 前向逐步加法模型

设 F_0 为初始预测，Boosting 经过 T 轮得到

$$F_T(\mathbf{x}) = F_0(\mathbf{x}) + \sum_{t=1}^T \alpha_t h_t(\mathbf{x}), \quad (6.6)$$

其中 h_t 是第 t 个成员， α_t 控制其贡献。为使复杂度惩罚对应真正加入模型的函数，把本轮增量记为 $f_t = \alpha_t h_t$ 。给定损失 ℓ ，理想化的第 t 轮直接优

化增量：

$$f_t \in \arg \min_{f \in \mathcal{F}} \sum_{i=1}^n \ell(y_i, F_{t-1}(\mathbf{x}_i) + f(\mathbf{x}_i)) + \Omega_t(f). \quad (6.7)$$

这里 $\mathcal{F} = \{\alpha h : \alpha \in \mathbb{R}, h \in \mathcal{H}\}$ 是由成员函数族 $\mathcal{H}$ 生成的增量函数族， Ω_t 是相应复杂度惩罚，也可以取零。对于树，叶数惩罚限制结构规模，叶输出的范数惩罚限制增量幅度；后者必须作用于 f 的叶输出，不能只惩罚仍可与 α 相互缩放的 h 。前向逐步训练固定已经加入的成员，只优化本轮增量；它避免一次性联合搜索全部函数，却也不等于求得式(6.6)在所有成员和权重上的全局最优解。后文的梯度拟合、二阶近似和额外收缩也不等于精确求解这一理想目标。

不同 Boosting 方法的主要差别，可以从“当前不足怎样变成下一轮训练信号”来判断。AdaBoost 改变训练样本的权重，使当前错分记录在下一轮具有更大影响；梯度提升把损失对当前预测的负梯度作为伪响应；二阶提升树还利用局部曲率近似叶权重和分裂收益。只有平方损失下的负梯度等于普通响应残差，把所有 Boosting 概括为“反复拟合残差”会掩盖损失函数的作用。

6.3.2 AdaBoost

AdaBoost (adaptive boosting) 从带权训练样本出发，使每一轮弱分类器回应当前加权分布。考虑二分类标签 $y_i \in \{-1, 1\}$ 和成员 $h_t(\mathbf{x}) \in \{-1, 1\}$ 。初始样本权重为 $w_i^{(1)} = 1/n$ ，第 t 轮成员的加权错误率为

$$\epsilon_t = \sum_{i=1}^n w_i^{(t)} \mathbb{I}_{\{y_i \neq h_t(\mathbf{x}_i)\}}. \quad (6.8)$$

当 $0 < \epsilon_t < 1/2$ 时，成员投票权重取

$$\alpha_t = \frac{1}{2} \log \frac{1 - \epsilon_t}{\epsilon_t}, \quad w_i^{(t+1)} = \frac{w_i^{(t)} \exp[-\alpha_t y_i h_t(\mathbf{x}_i)]}{Z_t}, \quad (6.9)$$

其中 Z_t 使新权重和为 1。错分样本满足 $y_i h_t(\mathbf{x}_i) = -1$ ，权重乘上 e^{α_t} ；正确样本的权重乘上 $e^{-\alpha_t}$ 。若 $\epsilon_t = 0$ ，在这些正权重下当前成员已分对全部训练样本，便直接输出 h_t 并停止，不再计算发散的 α_t 或执行归一化更新；这与第二卷“基础、理论和可信性”的“二分类学习的可学习性”章“集成学习”节的约定一致。其余情况下，最终分类器在预先固定平局规则后按 $\text{sign}(\sum_t \alpha_t h_t(\mathbf{x}))$ 决策。若成员不能在当前权重下取得小于 $1/2$ 的错误率，标准更新就无法获得正的成员贡献，需要停止、调整成员训练或采用相应变体。

图6.5展示了式(6.9)形成的反馈回路。当前分类结果先改变样本权重，再由归一化后的权重决定下一轮成员看到的训练分布；错分记录因而获得更

大的后续影响。

第 t 轮：分类结果决定第 $t+1$ 轮的训练分布




图 6.5 AdaBoost 的样本权重更新。分类结果把样本分成正确与错分两路，两路缩放后的权重汇合并归一化，形成下一轮训练分布。实线表示常规训练与正确分类样本的更新路径，红色虚线强调错分样本被放大的路径。

这一更新也可以从指数损失解释。令 $F(\mathbf{x}) = \sum_t \alpha_t h_t(\mathbf{x})$ ，经验目标为

$$\sum_{i=1}^n \exp[-y_i F(\mathbf{x}_i)].$$

固定 F_{t-1} 后选择 h_t 与 α_t ，在 $0 < \epsilon_t < 1/2$ 时可以导出式(6.9)。因此，样本重加权不是与目标函数无关的经验技巧，而是指数损失下前向逐步加法建模的结果⁸。

指数权重会持续放大难以正确分类的训练记录。若这些记录代表真实而稀少的边界情形，重新分配注意力可能有用；若它们来自标签错误或异常观测，后续成员可能反复追逐不可修正的噪声。训练错误下降还只说明组合在当前样本上的拟合变化，不能替代新样本风险。弱学习条件、训练错误界及投票间隔的泛化分析见第二卷“基础、理论和可信性”的“二分类学习的可学习性”章“集成学习”节；这里更关心更新如何形成可使用的模型。

多分类 AdaBoost 需要重新定义成员错误与类别得分，回归变体则要用响应误差决定样本权重和预测聚合。它们保留序贯重加权思想，却不再直接使用上述二分类推导。比较这些变体时，应按第3章或第2章的输出和损失分别评价，不能只沿用二分类准确率。

6.3.3 梯度提升机与 GBDT

AdaBoost 的指数损失给出了特定重加权规则。若任务需要平方损失、对数损失或其他关于预测可微的目标，可以直接询问：当前预测沿哪个函数

⁸ Y. Freund, R. E. Schapire, *A Decision-Theoretic Generalization of On-Line Learning and an Application to Boosting* In Journal of Computer and System Sciences, 1997, vol. 55, no. 1, pp. 119–139; J. Friedman, T. Hastie, R. Tibshirani, *Additive Logistic Regression: A Statistical View of Boosting* In The Annals of Statistics, 2000, vol. 28, no. 2, pp. 337–407

方向变化, 经验损失下降最快? **梯度提升机** (gradient boosting machine, GBM) 用基学习器逼近这个负梯度方向, 从而把序贯加法扩展到更一般的损失⁹。

通常从使训练损失最小的常数预测开始:

$$F_0(\mathbf{x}) = c_0, \quad c_0 \in \arg \min_c \sum_{i=1}^n \ell(y_i, c). \quad (6.10)$$

平方损失下 c_0 是响应均值。这里要求存在有限的最小化点; 若某种损失与数据组合使最优常数趋于无穷, 就需约束预测范围或另定有限初始化。

在第 t 轮, 对每个训练样本计算**伪残差** (pseudo-residual), 即损失在当前预测处的负导数:

$$r_i^{(t)} = - \left. \frac{\partial \ell(y_i, z)}{\partial z} \right|_{z=F_{t-1}(\mathbf{x}_i)}. \quad (6.11)$$

随后用平方误差把这些修正量拟合到成员函数族:

$$h_t \in \arg \min_{h \in \mathcal{H}} \sum_{i=1}^n (r_i^{(t)} - h(\mathbf{x}_i))^2. \quad (6.12)$$

这是对负梯度的平方拟合, 不是用原任务损失把 $r_i^{(t)}$ 当成新标签; 树的贪心生长通常只近似求解这一子问题。固定 h_t 后, 可以按原损失做整体线搜索, 在最小值存在时取

$$\alpha_t \in \arg \min_{\alpha} \sum_{i=1}^n \ell(y_i, F_{t-1}(\mathbf{x}_i) + \alpha h_t(\mathbf{x}_i)). \quad (6.13)$$

此处 α_t 是整棵树或整个成员共享的一个标量。加入预先选择的收缩系数 $\eta \in (0, 1]$ 后,

$$F_t(\mathbf{x}) = F_{t-1}(\mathbf{x}) + \eta \alpha_t h_t(\mathbf{x}). \quad (6.14)$$

当 $\ell(y, z) = \frac{1}{2}(y - z)^2$ 时, 式(6.11)给出 $y_i - F_{t-1}(\mathbf{x}_i)$, 恰好是普通残差。分类时则要先明确得分与概率的关系。例如二分类采用 $y_i \in \{0, 1\}$, 令 F 表示对数几率 (logit), 相应概率与二项对数损失为

$$p = \sigma(F) = \frac{1}{1 + e^{-F}}, \quad \ell(y, F) = \log(1 + e^F) - yF.$$

由于 $\partial \ell / \partial F = \sigma(F) - y$, 第 t 轮的伪残差为

$$r_i^{(t)} = y_i - p_i^{(t-1)}, \quad p_i^{(t-1)} = \sigma(F_{t-1}(\mathbf{x}_i)).$$

例如 $y_i = 1$ 而当前概率为 0.3 时, 伪残差是 0.7。成员拟合的是损失关于得分的连续修正量, 增量按式(6.14)加到 F 上, 再由 Sigmoid 换算为新概率; 不能把 0.7 直接加到概率上。

⁹ J. H. Friedman, *Greedy Function Approximation: A Gradient Boosting Machine* In The Annals of Statistics, 2001, vol. 29, no. 5, pp. 1189–1232

若 h_t 采用回归树, 就得到**梯度提升决策树** (gradient boosting decision tree, GBDT)。除了整体线搜索, 还可以保留平方拟合得到的叶区域 $\mathbf{R}_1^{(t)}, \dots, \mathbf{R}_{L_t}^{(t)}$, 再按原损失分别求每片叶的增量。当各叶内存在有限最小化点时,

$$\begin{aligned} v_j^{(t)} &\in \arg \min_v \sum_{i: \mathbf{x}_i \in \mathbf{R}_j^{(t)}} \ell(y_i, F_{t-1}(\mathbf{x}_i) + v), \\ F_t(\mathbf{x}) &= F_{t-1}(\mathbf{x}) + \eta \sum_{j=1}^{L_t} v_j^{(t)} \mathbb{I}\{\mathbf{x} \in \mathbf{R}_j^{(t)}\}. \end{aligned} \quad (6.15)$$

这里 L_t 是叶数, 各叶的 $v_j^{(t)}$ 替换原树的输出, 不是同一个 α_t 的不同写法; 这种逐叶更新替代整体线搜索, 而非在其后再乘一轮叶权重。若叶内最优值只能在无穷处逼近, 则需限制叶输出或引入相应正则, 不能直接把无穷值代入更新。“回归树”描述成员拟合连续修正量的计算角色, 整体任务仍可以是分类。

第2.1.3节的分位数损失 $\ell(y, z) = \rho_\tau(y - z)$ 在 $z = y$ 处不可微, 不能处处使用式(6.11)。分位数提升可改用负次梯度, 例如约定

$$r_i^{(t)} = \tau - \mathbb{I}\{y_i < F_{t-1}(\mathbf{x}_i)\}, \quad 0 < \tau < 1. \quad (6.16)$$

等号处的负次梯度可取 $[\tau - 1, \tau]$ 内任意值, 这里选端点 τ 。常数初始化取样本 τ 分位数, 仍用平方误差拟合上述修正量; 逐叶更新则最小化原分位数损失, 故 $v_j^{(t)}$ 取该叶内普通残差 $y_i - F_{t-1}(\mathbf{x}_i)$ 的 τ 分位数, 而不是伪残差的均值。

学习率、轮数与单树复杂度共同决定加法函数。较小学习率缩小每轮变化, 通常需要更多轮才能达到相近训练目标; 较深的树可以在单轮表达更高阶交互, 也会扩大每轮容量。行采样和列采样进一步引入随机性, 早停则依据独立验证轨迹选择轮数。不存在只调其中一个参数就能固定其他参数作用的普遍规则。

GBM 的轮次具有数据依赖, 不能像 Bagging 成员那样全部并行。单轮内部仍可并行统计不同特征或候选分裂。训练损失随轮次下降、优化过程趋于稳定和测试风险达到较小值是三件不同的事; 若轮数、损失、树结构和早停规则都根据同一验证集反复调整, 还要把这种选择纳入最终评价。

6.3.4 XGBoost

经典梯度提升用一阶负梯度给出拟合方向。**XGBoost** 在正则化加法树目标中进一步使用二阶局部近似, 并围绕稀疏输入、近似分裂和内存访问设计训练系统¹⁰。这三层需要分开理解: 二阶目标决定怎样评价一棵候选树, 分裂算法近似搜索树结构, 系统机制则决定统计量怎样高效计算。

设第 t 棵树为 f_t , 损失在当前预测 $F_{t-1}(\mathbf{x}_i)$ 处的一阶导与二阶导分别为

¹⁰ T. Chen, C. Guestrin, *XGBoost: A Scalable Tree Boosting System* In Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 2016, pp. 785–794

$g_i^{(t)}$ 和 $s_i^{(t)}$ 。去掉与 f_t 无关的常数后，本轮目标近似为

$$\tilde{\mathcal{L}}^{(t)} = \sum_{i=1}^n \left[g_i^{(t)} f_t(\mathbf{x}_i) + \frac{1}{2} s_i^{(t)} f_t^2(\mathbf{x}_i) \right] + \gamma L + \frac{\lambda}{2} \sum_{j=1}^L v_j^2, \quad (6.17)$$

其中 L 是叶数， v_j 是第 j 片叶的输出， γ 惩罚新增叶， λ 约束叶权重。若 I_j 表示落入第 j 片叶的样本索引，记

$$G_j = \sum_{i \in I_j} g_i^{(t)}, \quad S_j = \sum_{i \in I_j} s_i^{(t)}.$$

在 $S_j + \lambda > 0$ 时，固定树结构的最优叶权重为

$$v_j^* = -\frac{G_j}{S_j + \lambda}. \quad (6.18)$$

把一个父叶分成左右子叶时，相应近似目标下降量为

$$\text{Gain} = \frac{1}{2} \left[\frac{G_L^2}{S_L + \lambda} + \frac{G_R^2}{S_R + \lambda} - \frac{(G_L + G_R)^2}{S_L + S_R + \lambda} \right] - \gamma. \quad (6.19)$$

式(6.19)把当前损失的梯度、曲率与树复杂度放在同一个分裂准则中。它是局部二阶近似下的增益，不表示贪心生长已经找到所有树结构中的全局最优。

图6.6把一阶梯度提升与 XGBoost 的二阶树评分放在同一计算链中。左图回答新成员拟合什么，右图回答候选树结构怎样利用梯度统计得到叶权重和分裂增益；二阶统计扩展了本轮目标的近似信息，但没有改变逐轮加法更新的外层结构。


精确分裂搜索遍历排序后的候选特征值；近似搜索则先用带权分位数草图构造候选切分，再汇总梯度统计。稀疏感知搜索为缺失值学习默认方向，列采样减少每轮需要检查的特征。块式存储、缓存感知访问、并行统计和外存计算改变的是实现代价，不改变式(6.17)所定义的学习对象。工程改进能否转化为当前硬件和预算下的速度收益，需要实测。

6.3.5 LightGBM

当样本和特征很多时，逐值搜索分裂会反复扫描大量候选。**LightGBM** 以直方图训练为基础，把连续特征映射到有限个桶，并在桶级别累计梯度和曲率。构造直方图仍要访问节点样本，但候选分裂只需扫描桶；已知父节点和一个子节点的直方图时，还可以用差分得到另一个子节点的统计量。分桶减少存储和候选数，也引入离散化误差。

树的生长顺序进一步改变计算分配。按层生长同时扩展某一深度上的叶，按叶生长则每次选择当前增益最大的叶继续分裂。在相同叶数下，后

(a) 梯度提升：把损失方向变成新成员



(b) XGBoost：二阶统计进入树评分




图 6.6 梯度提升与 XGBoost 中的本轮修正。左图中，损失对当前预测的负梯度形成伪残差，新成员拟合该信号后更新组合；右图中，XGBoost 按候选分裂聚合一阶导与二阶导，再由同一组叶统计计算叶权重和分裂增益。复杂度项 $\gamma T + \lambda \|\mathbf{w}\|_2^2 / 2$ 使 λ 约束叶权重，并使 γ 惩罚新增叶。该图描述局部优化机制，不表示贪心树结构是全局最优。

者把容量集中到训练目标下降较大的局部区域，可能形成深度不均衡的树。叶数、叶内最小样本量和最大深度因此需要联合约束；训练损失下降更快不等于测试风险必然更小。

LightGBM 论文进一步提出两种针对大规模数据的近似。**单边梯度采样** (gradient-based one-side sampling, GOSS) 保留绝对梯度较大的样本，从绝对梯度较小的样本中随机抽取一部分，并在分裂统计中重新加权后者；它近似的是用于选择分裂的数据统计。例如，在小梯度组内等概率抽取一半样本，就把被抽中者对梯度和的贡献乘二，以补偿未采样部分。一般地，样本以概率 $p > 0$ 被保留时，其贡献乘以 $1/p$ ；给定本轮梯度和候选分区，这种逆包含概率加权可无偏估计相应的梯度和，但不意味着由平方、比值或择优操作得到的分裂增益也无偏。

互斥特征捆绑 (exclusive feature bundling, EFB) 把很少同时非零的稀疏特征编码到较少的组合特征中，近似减少有效特征数。GOSS、EFB 和直方图分别作用于样本、特征与候选阈值，不能合并成一个笼统的“降采样”步骤¹¹。

图6.7按近似对象并列这三种机制。直方图压缩候选阈值，GOSS 压缩参与分裂统计的样本，EFB 压缩稀疏特征表示；读者据此可以分别追踪每种近似改变了哪一项计算。

这些机制的效果依赖梯度分布、特征稀疏性、桶数、冲突处理和硬件实现。论文中的速度与精度比较支持相应实验条件下的结论，不构成 LightGBM 相对其他实现的无条件排序。公平比较应固定损失、搜索预算和早停规则，并记录离散化与采样设置。

¹¹ G. Ke, Q. Meng, T. Finley, T. Wang, W. Chen, W. Ma, Q. Ye, T.-Y. Liu, *LightGBM: A Highly Efficient Gradient Boosting Decision Tree* In *Advances in Neural Information Processing Systems*, 2017, pp. 3146–3154




图 6.7 LightGBM 中三种作用位置不同的计算近似。直方图把连续取值映射到有限桶，GOSS 保留 $|g_i|$ 较大的样本，并抽取、重加权部分 $|g_i|$ 较小的样本，EFB 把很少同时非零的特征编码为较少的捆绑特征。图中点数、桶数与非零位置均为机制示意。

6.3.6 CatBoost

高基数类别特征若全部展开为独热变量，会增加特征规模；把类别直接映射为整数，又会引入原本不存在的次序。另一种做法是用同类别样本的响应均值编码，但若样本自己的 y_i 参与其编码，模型就能从输入中间看到待预测标签。这种**目标泄漏**（target leakage）会使训练特征与部署特征的构造条件不同。

CatBoost 用随机排列建立**有序目标统计**（ordered target statistic）。设 c_i 为样本 i 的某个类别值，用 $\pi(j)$ 表示样本 j 在随机排列中的位置；对当前样本只使用排列中位于它之前且类别相同的记录：

$$z_i = \frac{\sum_{j: \pi(j) < \pi(i)} \mathbb{I}\{c_j = c_i\} y_j + ap}{\sum_{j: \pi(j) < \pi(i)} \mathbb{I}\{c_j = c_i\} + a}. \quad (6.20)$$

其中 p 是先验统计量， $a > 0$ 控制平滑。样本自身的标签不会进入 z_i ；部署时则可使用训练集中的类别统计。低频类别仍会产生较大估计波动，平滑、多个排列和类别组合需要共同考虑。

图6.8用一个排列位置说明这种隔离。计算当前类别 A 样本的编码时，只允许排列前缀中同为类别 A 的标签进入统计量；其他类别、当前标签和排列后缀都不参与这次编码。

有序提升把相同的前缀思想用于梯度估计。直观地说，计算某个训练样本的当前预测与伪残差时，只使用排列中位于该样本之前的记录形成相应模型，减少“同一样本既参与拟合当前模型，又用于评价当前模型”的预测偏移。实际算法通过多个排列和前缀模型实现这一约束，训练状态与计




图 6.8 CatBoost 有序目标统计的前缀约束。这里 $\pi(j)$ 表示样本 j 在随机排列中的位置；计算当前样本 i 的编码时，只有满足 $\pi(j) < \pi(i)$ 且 $c_j = c_i$ 的标签通过实线汇入统计量。其他类别、当前标签和后续记录均不连接到统计量，表示它们在本次编码中被隔离。样本索引与类别符号仅用于说明机制。

算量也比普通单序列提升更复杂¹²。

CatBoost 常使用**对称树**（symmetric tree），即同一深度的所有节点采用相同分裂条件。深度为 d_{tree} 的完整对称树至多有 $2^{d_{\text{tree}}}$ 片叶，路径可以编码为固定长度的二进制选择。这种结构便于批量预测，也限制了单棵树可表达的分区形状。类别编码、有序提升和对称树分别处理输入构造、序贯估计偏移和成员结构，不能把某一项的作用归给整个系统。

6.3.7 模型对比与总结

表6.2先固定共同的序贯加法结构，再比较各方法修改哪一层。AdaBoost 由加权分类错误生成样本权重；GBM 由损失梯度生成伪残差；XGBoost 对正则化树目标作二阶近似；LightGBM 进一步压缩分裂统计的计算；CatBoost 重点处理类别统计与序贯估计中的目标泄漏。后四者之间存在实现重叠，表中只列代表性机制，不把软件当前支持的全部选项写成永恒差异。

¹² L. Prokhorenkova, G. Gusev, A. Vorobev, A. V. Dorogush, A. Gulin, *CatBoost: Unbiased Boosting with Categorical Features* In *Advances in Neural Information Processing Systems*, 2018, pp. 6638–6648

方法	本轮修正信号	典型成员	目标近似	树生长或分裂	类别特征重点	主要约束
AdaBoost	加权错分	树桩或浅分类树	指数损失下的解析更新	由成员算法决定	需另行编码	对持续错分记录敏感
GBM / GBDT	负梯度伪残差	回归树	一阶函数方向与叶内优化	通常贪心树生长	需随实现处理	学习率、轮数与树复杂度耦合
XGBoost	一阶导与二阶导	正则化回归树	二阶局部目标	精确或分位数候选；稀疏默认方向	依实现与版本而定	轮次串行，近似与系统配置影响成本
LightGBM	桶级梯度统计	直方图回归树	通常使用二阶统计	按叶生长；直方图候选	支持类别分组，机制依实现	分桶、GOSS 与 EFB 引入近似条件
CatBoost	有序统计与有序梯度	对称树	梯度或二阶统计	同层共享分裂条件	有序目标统计与组合	多排列和前缀状态增加训练成本

表 6.2 Boosting 代表方法的机制比较。GBM 是一般框架，GBDT 指使用回归树成员的实例；XGBoost、LightGBM 和 CatBoost 是树提升的具体模型与系统，不能与 Boosting 这一上位类别并列。

随机梯度提升在每轮使用训练子样本，DART 随机暂时移除部分已有树后计算修正，LogitBoost 则从加法 Logistic 回归推导更新¹³。理解这些扩展时，可以询问它改变了训练样本、已有成员、损失近似还是树结构。Boosting 能够沿训练目标定向增加容量，却仍采用预先规定的加法组合形式；若已有成员来自不同模型族，并希望从它们的样本外表现中学习组合方式，就进入 Stacking 的范围。

6.4 基于 Stacking 的集成

Bagging 预先规定平均或投票，Boosting 在训练中形成加法权重；二者的成员生成机制与组合方式紧密绑定。若已经有线性模型、近邻模型、随机森林和梯度提升树等异质候选，还可以把它们的预测视为新特征，再训练一个模型决定怎样组合。**Stacking** (stacked generalization, 堆叠) 采用这种两层结构：基学习器产生一级预测，**元学习器** (meta-learner) 把这些预测映射为最终输出¹⁴。

6.4.1 Stacking

6.4.1.1 为什么不能直接使用训练内预测

设第 m 个成员模型为 h_m 。若直接在完整训练集上拟合 h_m ，再把 $h_m(\mathbf{x}_i)$ 作为样本 i 的元特征，元学习器看到的是成员对自身训练数据的预测。一个容量很大的成员可能近乎记住训练标签，元学习器便会高估它在新样本上的可靠性。问题不在于元学习器“多看了一列数据”，而在于这列特征的生成条件与部署时不同。

¹³ J. H. Friedman, *Stochastic Gradient Boosting* In Computational Statistics & Data Analysis, 2002, vol. 38, no. 4, pp. 367–378; K. V. Rashmi, A. Gilad-Bachrach, *DART: Dropouts Meet Multiple Additive Regression Trees* In Proceedings of the Eighteenth International Conference on Artificial Intelligence and Statistics, 2015, pp. 489–497; J. Friedman, T. Hastie, R. Tibshirani, *Additive Logistic Regression: A Statistical View of Boosting* In The Annals of Statistics, 2000, vol. 28, no. 2, pp. 337–407

¹⁴ D. H. Wolpert, *Stacked Generalization* In Neural Networks, 1992, vol. 5, no. 2, pp. 241–259; L. Breiman, *Stacked Regressions* In Machine Learning, 1996, vol. 24, no. 1, pp. 49–64

Stacking 通常用交叉验证生成**折外预测**(out-of-fold prediction, OOF prediction)。把训练样本划分为 K 个互不相交的折 $V_1, \dots, V_K$ 。对每个成员类型 m 和每个折 k , 只用 $D_n \setminus V_k$ 训练临时模型 $h_m^{(-k)}$, 再预测 V_k 中的样本。若样本 i 属于 $V_{k(i)}$, 元特征定义为

$$z_{i,m} = h_m^{(-k(i))}(x_i). \quad (6.21)$$

把所有成员的折外预测拼成 $\mathbf{z}_i = (z_{i,1}, \dots, z_{i,M})^\top$, 再由元学习算法 g 训练

$$g = \mathcal{G}(\{(\mathbf{z}_i, y_i)\}_{i=1}^n).$$

这样, 每个 $z_{i,m}$ 都来自未使用样本 i 标签拟合的临时成员。图6.9展示了折外矩阵的形成过程。

三折轮换




图 6.9 三折 Stacking 的折外特征构造。每一折轮流作为留出折, 临时成员只在其余两折训练, 并为留出折产生预测; 拼接三次预测得到完整折外矩阵 $\mathbf{Z}$, 元学习器以 $\mathbf{Z}$ 为输入并使用对应标签拟合。部署阶段的基成员还需按预先规定的方式重训或保留。

分类成员若输出 C 维概率向量, 一个成员通常贡献 C 列元特征; 二分类时也可以只保留一个类别概率。硬标签丢失了置信程度, 未经校准的得分又可能量纲不同。采用哪种输出必须在训练和部署阶段保持一致, 元学习器的正则化也要适应该尺度与相关性。

6.4.1.2 部署模型与全量训练集重训

折外矩阵用于训练元学习器, 但部署时还需要能预测新输入的基成员。一种做法是在完整训练集上重新拟合每类基学习器 $\hat{h}_m$, 预测

$$\hat{y} = g(\hat{h}_1(x), \dots, \hat{h}_M(x)).$$

这种做法充分使用训练数据，却使元学习器训练时看到的折内模型预测与部署时的全量模型预测存在有限样本差异。另一种做法是保留每折模型，对新输入先在折内模型间平均，再交给元学习器；其输入条件更接近折外构造，但需要保存和运行更多模型。

两种部署方案都可以成立，关键是事先固定并完整评价实际链路。基学习器的特征处理、类别编码和超参数搜索必须在相应训练折内完成。若先用全部数据选择特征或编码，再只把模型拟合放进交叉验证，信息仍可能从留出折进入元特征。

6.4.2 Blending

Blending 用一次固定留出替代 K 折交叉验证。将可用于开发的数据分为基训练集 D_{base} 和组合训练集 D_{blend} ；基成员只在 D_{base} 上拟合，对 D_{blend} 产生预测，元学习器再以这些预测和对应标签训练。每个基成员只需完成一次用于元特征的拟合，流程比完整 Stacking 短。

代价是元学习器只能使用 D_{blend} 中的样本，基成员也暂时失去这部分训练数据。划分较小时，元学习器估计不稳定；划分较大时，基成员训练信息减少。多次随机划分并平均可以减小单次划分的偶然性，但它重新引入多次训练，已经不再具有单次 Blending 的全部成本优势。

部署时若把 D_{blend} 加入基成员重新训练，基预测分布可能相对元学习器训练时发生变化；若不加入，则没有充分利用已有标签。这个取舍不能由“Blending 更简单”自动解决，需要在流程中明确重训方式，并用冻结后的验证或测试数据评价完整组合。

6.4.3 受约束线性 Stacking

元学习器不一定要很复杂。对回归输出，可以在折外矩阵 $\mathbf{Z} \in \mathbb{R}^{n \times M}$ 上学习线性组合

$$(\hat{b}, \hat{\mathbf{w}}) \in \arg \min_{b, \mathbf{w}} \frac{1}{n} \sum_{i=1}^n \ell(y_i, b + \mathbf{w}^\top \mathbf{z}_i) + \lambda \|\mathbf{w}\|_2^2. \quad (6.22)$$

也可以约束组合权重，但不同约束的含义不同。在 $b = 0$ 时，仅要求 $w_m \geq 0$ 得到非负线性组合，仍可能放大预测；仅要求 $\sum_m w_m = 1$ 得到仿射组合，仍可因负权重而外推。只有同时满足 $b = 0$ 、 $w_m \geq 0$ 和 $\sum_m w_m = 1$ ，才是成员预测的凸组合，输出必定位于成员预测的凸包内。非负约束排除了成员之间的正负抵消，归一化进一步限制整体尺度；但若有效校正需要负权重或截距，这些约束也会增加偏差。

权重大小同时受输出尺度、成员相关性和损失函数影响。两个成员预测近乎相同，线性模型可以在它们之间任意分配相近作用；一个成员输出的

数值范围更大，也会改变未标准化正则项下的权重。因此， $\hat{w}_m$ 不能直接解释为成员的独立重要性。对同一类别集合上的概率向量，使用同一组满足上述凸组合条件的权重逐类组合，结果仍位于概率单纯形内，却仍需检查样本外校准。

6.4.4 Super Learner

Super Learner 把候选学习器库、交叉验证风险与组合权重放进一个明确程序。给定预先规定的候选库和损失，先生成每个候选的折外预测，再在指定组合类中选择交叉验证风险较小的组合；组合类可以是最佳单成员、非负线性组合或其他受控元模型。

在独立同分布、损失有界或满足相应矩条件、候选库与交叉验证方案受控等条件下，Super Learner 的理论结果把其风险与候选组合类中的 oracle 风险联系起来：样本量增加时，交叉验证选择的组合能够渐近接近该库中最优候选或最优组合的风险¹⁵。这里的 oracle 只在预先给定的库和损失内比较，不表示找到了所有可测预测器中的最优模型。

三个条件不能混为同一句“组合必然优于成员”。候选库中需要存在有用且互补的预测；折外风险需要在当前数据制度下稳定估计；元学习器还要有足够样本控制自身复杂度。渐近 oracle 结论也不推出任意有限样本上都优于最佳成员。若数据存在时间、群组或空间依赖，交叉验证划分还必须与部署时的新样本定义一致。

¹⁵ M. J. van der Laan, E. C. Polley, A. E. Hubbard, *Super Learner In Statistical Applications in Genetics and Molecular Biology*, 2007, vol. 6, no. 1, pp. Article 25

6.4.5 模型对比与总结

表6.3比较 Stacking 家族的元特征来源与组合约束。标准 Stacking 和 Super Learner 都依赖折外预测；Blending 以一次留出降低训练次数；受约束线性 Stacking 说明“学习组合”不等于必须使用高容量元模型。模型名称之外，还应记录预处理、基模型重训和元输出类型，否则无法复现实际预测链路。

方法	元特征来源	数据利用	组合规则	主要成本	主要风险
Stacking	K 折折外预测	每个样本都产生元特征	可线性或非线性	每类成员需多次折内拟合	折外流程不完整造成泄漏
Blending	固定留出集预测	元学习器只用留出集	可线性或非线性	基成员用于元特征时只拟合一次	划分敏感与重训分布变化
受约束线性 Stacking	通常为折外预测	与所用划分一致	非负、和为一或正则化线性组合	组合层较轻量	约束可能排除有效校正
Super Learner	交叉验证预测与风险	由交叉验证方案决定	在预定库和组合类中选择	候选库越大，训练与选择成本越高	oracle 范围和有限样本被夸大

表 6.3 Stacking 及其代表性变体。表中“数据利用”描述元学习器训练阶段；部署前是否用完整开发数据重训基成员，还需作为流程的一部分单独规定。

多层 Stacking 把一层折外输出继续交给下一层，每增加一层都要重新保证当前样本没有通过上游拟合泄漏到本层特征。输入相关的门控组合则让权重随 $\mathbf{x}$ 变化，它与第6.5.2节的动态成员选择相邻，也与神经网络中的混合专家相接。它们增加了表达能力，同时扩大了数据划分、模型存储和调试成本；在两层组合尚未提供稳定新增价值时，没有理由仅凭层数增加继续扩展。

6.5 成员选择与集成简化

Bagging、Boosting 和 Stacking 先回答怎样形成组合。训练完成后，成员数量仍可能超过存储或延迟预算，也可能包含只在少数输入区域有用的模型。简化集成有三种不同目标：为所有输入固定一个较小成员子集，针对当前输入临时选择成员，或训练一个新的紧凑模型替代原集成。前两种方法保留部分原成员，第三种方法改变了部署模型。

图6.10沿部署对象区分这三种目标。静态选择把成员池缩成一个固定子集，动态选择保留成员池并让路由依赖当前输入，紧凑化则把完整集成的行为转移到新模型。后续评价资源收益时，需要测量图中实际部署的整条路径。




图 6.10 静态成员选择、动态成员选择与紧凑化改变的部署对象。静态选择为所有输入保留同一成员子集；动态选择根据输入改变运行成员或组合权重；紧凑化训练并部署新的学生模型。三种路径可能减少不同类型的成本，不能只用保留成员数比较。

6.5.1 静态成员选择

静态成员选择 (static ensemble selection) 给定已经训练好的候选池 $\{h_1, \dots, h_M\}$ ，选择一个对所有未来输入都相同的子集 $S \subseteq \{1, \dots, M\}$ 。若

$\mathcal{L}_{\text{val}}(S)$ 表示该子集按指定规则组合后的验证损失，可以写成

$$\hat{S} \in \arg \min_{S \subseteq \{1, \dots, M\}} \mathcal{L}_{\text{val}}(S) + \lambda_1 |S| + \lambda_2 C(S), \quad (6.23)$$

其中 $\lambda_1, \lambda_2 \geq 0$, $|S|$ 控制成员数, $C(S)$ 可以表示存储、单样本延迟或其他部署成本。这个组合优化通常随成员池大小指数增长, 需要用排序、前向加入、后向删除或其他近似搜索。

只按单成员验证损失排序, 容易保留许多行为相近的模型; 按当前组合的边际改进逐个加入成员, 可以同时感知成员质量与已有组合。允许重复选择某个成员时, 重复次数还形成离散权重。基于模型库的贪心集成选择就是这种做法的代表: 从一个初始组合出发, 每轮加入使验证指标改善最大的候选, 必要时使用多起点或装袋法减少搜索的不稳定性¹⁶。

成员选择与一般模型选择的区别在于, 式(6.23)固定了候选池及其预测, 只搜索哪些已训练成员共同部署。若同时改变基学习算法、特征处理和超参数, 搜索范围已经扩展为完整模型开发流程。候选池越大, 验证集上偶然出现有利组合的机会也越多; 选择所用数据不能同时充当最终测试。

分歧率、误差协方差等多样性指标可以缩小候选范围, 却不能替代任务损失。一个与其他成员高度不同但经常出错的模型, 可能增加分歧而降低组合质量。静态选择应直接评价选定组合的输出, 并在相同成员数或资源预算下与完整集成及单模型基线比较。

6.5.2 动态成员选择

静态选择假设同一成员子集适合所有输入。若成员在输入空间的不同区域各有所长, 可以先估计当前输入附近的成员能力, 再决定由谁预测。**动态分类器选择** (dynamic classifier selection, DCS) 为每个输入选择一个成员;**动态集成选择** (dynamic ensemble selection, DES) 选择一个成员子集或给出输入相关权重。

一种基本构造是准备独立的能力估计数据。对查询输入 $\mathbf{x}$, 在该数据中寻找非空邻域 $\mathcal{N}(\mathbf{x})$, 再以成员 m 在邻域内的正确率估计

$$\hat{c}_m(\mathbf{x}) = \frac{1}{|\mathcal{N}(\mathbf{x})|} \sum_{i \in \mathcal{N}(\mathbf{x})} \mathbb{I}\{h_m(\mathbf{x}_i) = y_i\}. \quad (6.24)$$

DCS 可以选择 $\hat{c}_m(\mathbf{x})$ 最大的成员, DES 则保留超过阈值的成员或按能力加权。局部正确率只是能力估计的一种方式, 还可以使用输出轮廓、分类间隔或由元模型学习的能力特征¹⁷。

这个流程新增了两个误差来源。邻域依赖输入表示与距离, 高维或分布稀疏时, 附近样本未必提供稳定的局部证据; 能力估计器也可能在有限数据上过拟合。成员训练数据、能力估计数据与最终测试数据需要分开, 所

¹⁶ R. Caruana, A. Niculescu-Mizil, G. Crew, A. Ksikes, *Ensemble Selection from Libraries of Models* In Proceedings of the Twenty-First International Conference on Machine Learning, 2004, pp. 18

¹⁷ K. Woods, W. P. Kegelmeyer, K. Bowyer, *Combination of Multiple Classifiers Using Local Accuracy Estimates* In IEEE Transactions on Pattern Analysis and Machine Intelligence, 1997, vol. 19, no. 4, pp. 405–410

有标准化和邻域参数都在相应开发流程内确定。

动态选择不一定降低端到端延迟。若系统必须先运行全部成员才能构造输出轮廓，再选择其中几个聚合，成员计算已经发生；基于输入邻域的方法还增加了检索成本。只有能够在运行昂贵成员之前完成路由，或动态组合确实改善资源分配时，成员数减少才可能转化为实际延迟收益。

6.5.3 从集成模型到紧凑模型

静态与动态选择仍依赖原成员池。另一条路线是训练一个新的**紧凑模型** (compact model)，使其逼近完整集成的输入输出映射。早期模型压缩工作已经用大型集成的输出训练较小模型；知识蒸馏随后把这种教师到学生的传递扩展为常用训练形式¹⁸。

设完整集成为教师 H ，紧凑模型为学生 s_θ 。对回归，可以组合真实响应损失与教师拟合损失：

$$\min_{\theta} \sum_{i=1}^n [\alpha \ell(y_i, s_\theta(\mathbf{x}_i)) + (1 - \alpha) \ell(H(\mathbf{x}_i), s_\theta(\mathbf{x}_i))], \quad (6.25)$$

其中 $\alpha \in [0, 1]$ 控制真实标签与教师输出的作用。分类时可以拟合教师的完整类别分布；温度缩放会使非最大类别之间的相对关系更容易进入训练信号，但温度、损失权重与部署概率仍须分别选择和校准。

学生训练输入可以来自原训练集、额外未标注样本或经过说明的合成样本。教师只在这些输入上提供目标，输入覆盖不足时，学生即使在压缩数据上高度一致，也可能在其他区域偏离教师。学生容量过小会产生逼近误差，容量很大则可能无法达到预期资源节省。

紧凑化至少需要四类证据。预测一致性衡量学生是否复现教师输出；任务性能检查学生面对真实标签的风险；概率评价检查蒸馏后的得分是否仍可解释；资源测量确认模型大小、内存和延迟是否实际下降。教师与学生高度一致不自动保证二者具有相同新样本风险，学生也可能因真实标签项、正则化或额外数据而在部分样本上优于教师。原集成的成员级解释、袋外诊断和理论条件不能直接转移到新模型。

¹⁸ C. Bucila, R. Caruana, A. Niculescu-Mizil, *Model Compression* In Proceedings of the 12th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 2006, pp. 535–541; G. Hinton, O. Vinyals, J. Dean, *Distilling the Knowledge in a Neural Network* In arXiv preprint arXiv:1503.02531, 2015

6.6 模型选择与评价

6.6.1 方法比较

表6.4按成员来源、依赖和组合规则比较本章方法。相同的“100个成员”在不同方法中不是同一计算单位：Bagging 的一棵深树负责完整预测，Boosting 的一棵浅树只提供增量，Stacking 的一个成员甚至可能是已经包含许多树的随机森林。容量与成本必须沿完整训练和预测路径衡量。

方法	成员来源	成员间依赖	组合规则	训练并行性	推理路径	主要失效来源
Bagging	重采样或随机权重下的同类成员	给定原训练集后可独立生成	平均、投票或固定加权	成员间可并行	通常运行全部成员	成员稳定或共同偏差占主导
随机森林／Extra Trees	样本、特征与阈值的随机树	树之间无序贯依赖	平均或投票	树间可并行	运行全部或选定树	随机化削弱单树，或相关性仍高
AdaBoost	当前样本权重下的弱分类器	第 t 轮依赖前轮权重	训练中确定的加权投票	轮次串行	累加全部或截断成员	噪声记录持续获得大权重
梯度提升树	当前损失梯度下的回归树	第 t 轮依赖 F_{t-1}	收缩后的加法得分	轮次串行，单轮可并行	顺序累加树输出	损失、轮数、树复杂度与采样失配
Stacking	同质或异质候选模型	基成员可独立，元层依赖折外预测	学习得到的元模型	折与成员可部分并行	运行基成员后再运行元模型	元特征泄漏、成员冗余或元层过拟合
动态选择／紧凑化	已训练成员池或教师集成	依赖能力估计或教师输出	输入相关选择或新学生模型	依具体训练流程而定	选择部分成员，或只运行学生	路由失准、覆盖不足或逼近误差

表 6.4 集成方法的属性导航。表中成本描述方法结构，不构成固定速度排序；实际结果还受成员模型、实现、硬件、数据规模与调参预算影响。

方法比较还要固定组合输出。回归的均值、分位数和分布预测不能共用一个误差口径；分类的硬标签、排序得分和概率也需要不同证据。一个集成若只改善准确率，不能据此声称概率校准或尾部代价同步改善。具体指标沿用表2.5和表3.7，本节补充集成特有的数据隔离与资源记录。

6.6.2 数据隔离与泄漏控制

集成流程会产生多种“没有直接用于某次拟合的预测”，但它们的职责不同：

- **袋外预测**来自未抽中当前样本的自助成员，用于 Bagging 内部诊断、置换重要性或相关构造。
- **折外预测**来自未使用当前折拟合的模型，用于训练 Stacking 元学习器，或为其他二阶段模型提供样本外特征。
- **能力估计预测**来自动态选择的独立开发数据，用于判断某个成员在当前输入附近是否可靠。
- **验证预测**用于选择成员数、树复杂度、学习率、组合约束、阈值与早停轮数。
- **测试预测**只在所有训练、选择、校准和部署规则冻结后产生，用于评价最终流程。

图6.11把五类预测放回各自的数据路径。前四类仍处在模型开发阶段，允许影响规定范围内的诊断、二阶段训练或选择；测试预测位于流程冻结之后，只负责评价最终链路。区分这些职责，比笼统地把它们都称为“样本外预测”更能暴露泄漏。




图 6.11 集成学习中的数据隔离与预测职责。每一行从预测或数据来源出发，经由相应隔离条件到达允许的用途；水平分隔线表示训练、调参、筛选、校准和部署规则已经冻结。测试数据位于分隔线之后，不能沿开发路径回流。

这些预测都可能在局部意义上“样本外”，却不能互相替代。折外矩阵参与元学习器训练，因而不是最终测试证据；袋外误差若反复用于选择随机森林参数，也已经参与模型开发；动态能力数据若同时训练成员，会高估局部能力。

泄漏还可能发生在模型拟合之前。缺失值填补、标准化、特征选择、目标编码和降维若利用了当前留出折，就会把信息带入折外预测。基成员调参、成员池筛选、元学习器调参和概率校准也要放在正确的数据层级。需要同时比较候选成员和组合规则时，可以在外层保留最终测试集，在内层训练折中完成全部预处理、调参及折外特征构造；时间、患者、用户或设备等依赖单位则按部署边界分组划分。

数据隔离不是要求为每一步机械切出一份新数据。样本有限时，可以通过嵌套交叉验证或交叉拟合复用开发样本，同时保持当前预测来自未用该样本拟合的路径。应记录每个预测由哪些样本训练的哪些模型产生，使元训练、选择与最终评价的角色可追溯。

6.6.3 预测质量与资源成本

集成结果至少要与三个基线比较：相同任务下的合理单模型、未简化的完整集成，以及满足同一资源限制的候选方法。只比较集成与其中最差成员，会夸大组合价值；只比较最终分数，又无法判断收益来自成员质量提升、错误依赖变化还是组合规则。

对 Bagging，可以同时报告代表性单成员损失、成员预测相关或双错率、集成损失以及损失随成员数的变化。对 Boosting，应区分训练损失、验证轨迹和最终测试结果，并记录早停轮数。对 Stacking，应比较各成员的折外表现、折外预测依赖、元模型的新增验证收益和全链路测试结果。多样性指标是诊断量，不应脱离任务损失单独优化。

概率输出需要额外检查。平均若干过度自信的概率，不保证得到可靠概率；AdaBoost 和梯度提升的累计得分也需要经过适当链接才能解释为概率。若使用后处理校准，校准器只能接收未用于拟合该预测的数据，并要把它作为部署链路的一部分，在最终测试集上报告对数损失、Brier 分数、可靠性及任务决策损失。

资源比较应记录完整过程，而不是只测单个成员。训练侧至少包括总计算量、墙钟时间、峰值内存、并行资源和调参次数；部署侧包括序列化模型大小、加载内存、单样本延迟、批量吞吐及预处理和路由开销。Bagging 的成员训练可以并行，但推理通常运行多个成员；Boosting 轮次串行，树内统计可并行；Stacking 既要运行基成员，又要运行元模型。静态选择、动态选择和紧凑化是否真正节省资源，只能由端到端测量回答。

6.6.4 从问题条件到候选方法

当单模型对训练样本、随机种子或局部分裂明显敏感，并且可以承担多个成员的存储与预测成本时，Bagging 是直接候选。树成员反复依赖少数强特征时，可以进一步比较随机森林；若阈值搜索成本较高且可以接受更强的随机化，再比较 Extra Trees。是否采用这些方法，应由固定任务上的单成员变化、成员依赖和组合收益共同支持。

当任务损失能够提供有意义的逐轮修正，并且训练流程可以承担序贯依赖时，可以考虑 Boosting。AdaBoost 适合检查重加权分类的机制；一般损失与树成员则进入 GBDT。XGBoost、LightGBM 和 CatBoost 的选择不应只依据名称：需要分别判断是否重视正则化二阶树目标与稀疏路径、直方图及大规模稀疏统计、或类别特征的有序统计，并在当前硬件和搜索预算下实测。

当候选模型已经产生互补的样本外预测，并且可以承担交叉验证与多模型部署成本时，Stacking 提供学习式组合。数据较少时，固定留出会压缩元训练样本，完整折外构造通常更充分；成员高度相关时，受约束线性

组合比高容量元模型更容易控制。Super Learner 的理论比较范围由候选库、损失和组合类共同决定，不能替代有限样本验证。

成员池超过部署预算时，再判断要保留什么对象。希望所有输入走同一条较短路径时采用静态成员选择；有可靠局部能力数据且路由开销可控时考虑动态选择；完整集成质量合格但任何成员子集都达不到预算时，可以训练紧凑模型。以上条件只负责缩小候选范围，最终选择仍来自相同数据制度、调参预算和资源口径下的新样本证据。

6.7 本章小结

多个模型能够互补，不是因为“数量多”本身，而是因为成员生成、错误依赖与组合规则共同改变了预测。Bagging 通过样本、特征或分裂随机性构造可并行成员，再用平均或投票削弱一部分训练波动；Boosting 让每轮成员依赖当前组合，沿选定损失逐步加入修正；Stacking 使用折外预测训练元学习器，使组合规则本身也由数据决定。三类机制可以嵌套，但各自的数据依赖、计算路径和失效原因不同。

成员池形成后，还可以改变部署规模。静态成员选择为所有输入固定同一子集，动态成员选择针对当前输入估计局部能力，紧凑化则训练一个新模型逼近完整集成。前两者仍需保留被选成员，后一种方法改变了部署模型；三者不能用同一个“剪枝”名称掩盖。

集成的最终证据来自冻结流程后的新样本评价。袋外预测服务于 Bagging 内部诊断，折外预测服务于 Stacking 的元特征构造，能力估计数据服务于动态选择；它们承担的职责不同，也都不能无条件替代最终测试。比较方法时还要固定调参预算，并同时报告任务损失、概率质量、模型大小和端到端延迟。后续神经网络模型部分将在这些共同原则上，进一步讨论由初始化、数据顺序与训练过程产生的神经网络集成。

第二部分

神经网络模型

Neural Network Models

神经网络概述

第二卷“基础、理论和可信性”的“模型简介”章介绍过一种邮件分类方法：统计促销提示词和外部链接，再用加权和计算分类得分。这个方法能够学习各项特征的权重，却要由我们决定统计什么。如果判断还依赖词语之间的搭配、否定关系或句子上下文，仅仅调整已有特征的权重，未必能够表达这些关系。一个自然的问题是：能否把构造特征也交给学习算法，让模型根据任务需要改变自己的输入表示？

人工神经网络（artificial neural network, ANN）用相互连接的计算单元完成这种变换：一个单元组合已有数值，多个单元形成新的表示，再把这些表示交给后续计算。连接中的参数可以根据数据调整。这里的“神经”来自生物神经系统的启发；理解一个人工网络时，仍需具体说明它计算什么、信息怎样传递、哪些量参与学习。

本章围绕这几个问题建立共同框架。可学习表示说明网络怎样改变预测所依据的信息，生物启发说明这些计算抽象保留了什么、简化了什么。历史部分考察表示、学习和计算条件怎样共同发展，类型部分则用不同分类依据区分网络的结构假设。读者只需用到前文的特征、参数、损失函数和函数复合；各类网络的详细结构与训练推导将在后续章节展开。

7.1 从人工特征到可学习的表示

先把邮件分类器画成一个小网络，如图 7.1 所示。两个输入 x_1, x_2 仍是促销提示词和外部链接的统计量，但不再直接加权得到分类得分。中间三个单元各自读取这两个数，加权求和、加上偏置，再作非线性变换，得到 h_1, h_2, h_3 ；输出单元将这三个数加权组合成得分 a 。中间这组单元称为**隐藏层**（hidden layer），因为它的数值由网络内部计算，而不是数据直接给出的输入或标签。这类具有一个或多个隐藏层、相邻层之间两两相连的逐层计算网络，称为**多层感知机**（multilayer perceptron, MLP）。图中的 2-3-1 分别表示输入、隐藏层和输出的单元数。




图 7.1 一个 2-3-1 多层感知机。两项输入先变成三个隐藏数值，再组合成一个分类得分。细线表示带权连接，箭头标出从左到右的计算方向；三个隐藏单元各作一次非线性变换，所有计算单元的偏置均省略。图只规定结构，权重尚未指定，也不要求某个隐藏单元预先代表某一种邮件特征。

围绕这个小网络，可以把学习中的三个问题分开。**表示能力**关心是否存在一组权重，使三个隐藏数值帮助输出端区分目标邮件；改变隐藏单元数，也会改变可选的计算。**优化**关心怎样根据训练邮件及其标签调整这些权重，让损失降低。**泛化**则关心训练后固定权重，面对未参与训练的新邮件时是否仍能作出可靠判断。画出网络还没有回答这三个问题，甚至原来的两项统计量也可能丢失判断所需的信息。下面从隐藏层怎样改变输入表示入手，再说明它与参数学习的联系。

7.1.1 特征变换与函数复合

线性得分是否够用，取决于它作用在哪种表示上。设输入为 $\mathbf{x} \in \mathbb{R}^d$ ，预先确定的特征变换为 $\phi: \mathbb{R}^d \rightarrow \mathbb{R}^m$ ，线性得分可以写成

$$f(\mathbf{x}) = \mathbf{w}^\top \phi(\mathbf{x}) + b, \quad (7.1)$$

其中 $\mathbf{w} \in \mathbb{R}^m$ 是权重， $b \in \mathbb{R}$ 是偏置。即使得分对 $\phi(\mathbf{x})$ 是线性的，只要特征变换包含平方、乘积等运算，它对原始输入也可以是非线性的。困难因而不只在分类器，还在于如何找到适合任务的 ϕ 。

神经网络把固定的特征变换换成带参数的变换。沿用前文的**表示学习** (representation learning) 概念，这意味着模型从数据中学习供后续任务使用的信息形式，而不只学习最后的预测权重。将表示变换记为 $\mathbf{r}_\theta: \mathbb{R}^d \rightarrow \mathbb{R}^m$ ，输出映射记为 g_ψ ，完整预测函数为

$$f_{\theta, \psi}(\mathbf{x}) = g_\psi(\mathbf{r}_\theta(\mathbf{x})), \quad (7.2)$$

其中 $\theta \in \mathbb{R}^p$ 和 $\psi \in \mathbb{R}^q$ 分别收集表示部分与输出部分的参数， p, q 是相应参数量。对于标量得分， g_ψ 可以仍是线性函数；它现在作用于模型自己构

造的表示。

表示部分通常由若干次变换组成。以具有 L 个表示层的网络为例，令 $\mathbf{h}^{(0)} = \mathbf{x}$ ，第 ℓ 层的输出为 $\mathbf{h}^{(\ell)} \in \mathbb{R}^{d_\ell}$ ，其中 $d_0 = d$ 。一种常见计算形式是

$$\begin{aligned} \mathbf{h}^{(\ell)} &= \sigma_\ell(\mathbf{W}_\ell \mathbf{h}^{(\ell-1)} + \mathbf{b}_\ell), \quad \ell = 1, \dots, L, \\ \mathbf{r}_\theta(\mathbf{x}) &= \mathbf{h}^{(L)}, \end{aligned} \quad (7.3)$$

其中 $\mathbf{W}_\ell \in \mathbb{R}^{d_\ell \times d_{\ell-1}}$ 、 $\mathbf{b}_\ell \in \mathbb{R}^{d_\ell}$ 分别是权重矩阵和偏置向量， $d_L = m$ 。本式中的 σ_ℓ 逐坐标作用，称为**激活函数** (activation function)，即在加权组合之后改变单元输出的函数。每个单元产生一个坐标；图 7.1 中的三个隐藏数值，就是这里 $L = 1$ 、 $d_1 = 3$ 时的 $\mathbf{h}^{(1)}$ 。

式(7.3)把函数复合落实为逐层计算：上一层的输出就是下一层的输入。若各层激活函数都是恒等函数，两层变换合起来为

$$\mathbf{W}_2(\mathbf{W}_1 \mathbf{x} + \mathbf{b}_1) + \mathbf{b}_2 = (\mathbf{W}_2 \mathbf{W}_1) \mathbf{x} + \mathbf{W}_2 \mathbf{b}_1 + \mathbf{b}_2。$$

结果仍是一次仿射变换，即线性变换加偏置。重复叠加这种层不会改变这一性质。非线性激活使不同输入范围能够产生不同响应，才让多层组合有机会表达原始坐标中的复杂关系。

示例 7.1 异或的表示变换 考虑四个二值输入 $\mathbf{x} = (x_1, x_2)^T \in \{0, 1\}^2$ ，目标在两个坐标不同时为 1、相同时为 0，这就是**异或** (exclusive OR, XOR)。设正类由 $w_1 x_1 + w_2 x_2 + b > 0$ 确定。若四个点都被正确分类，必须同时满足

$$\begin{aligned} b &\leq 0, & w_1 + w_2 + b &\leq 0, \\ w_1 + b &> 0, & w_2 + b &> 0. \end{aligned}$$

第一行来自两个负例，第二行来自两个正例。两条正类约束相加得到 $w_1 + w_2 + 2b > 0$ ，两条负类约束相加却得到同一表达式不大于 0，所以这样的线性得分不存在。

令 $\rho(a) = \max\{0, a\}$ ，它保留非负值、把负值置零，称为**整流线性单元** (rectified linear unit, ReLU) 的激活函数。构造两个隐藏单元

$$h_1 = \rho(x_1 - x_2), \quad h_2 = \rho(x_2 - x_1), \quad (7.4)$$

则四个输入的表达依次为

$$\begin{aligned} (0, 0) &\mapsto (0, 0), & (1, 1) &\mapsto (0, 0), \\ (1, 0) &\mapsto (1, 0), & (0, 1) &\mapsto (0, 1). \end{aligned}$$

在新表示中，用 $h_1 + h_2 > 1/2$ 判断正类就能全部分对。这组参数是为说明机制而手工构造的，并非一次训练的实验结果；它证明了隐藏表示可以解决原始坐标中的线性不可分问题。

图 7.2 给出这个例子的几何读法。变换没有修改标签，而是把两个负例送到同一个位置，把两个正例留在另外两个位置。输出层因此可以采用简单的分界。表示不必保留输入的每一项区别；在这个任务中，区分 $(0,0)$ 和 $(1,1)$ 并不是得到正确标签所必需的信息。




图 7.2 异或任务在变换前后的表示。圆点是标签为 0 的负例，方点是标签为 1 的正例。左侧两类点交错，无法用一条直线分开；右侧按式(7.4)变换后，两个负例重合，虚线 $h_1 + h_2 = 1/2$ 将两类分开。坐标和变换均为教学构造。

实际学习时，我们并不知道应该使用式(7.4)中的权重。给定训练样本 $S = ((\mathbf{x}_i, y_i))_{i=1}^n$ 和损失函数 ℓ ，可以把表示参数与输出参数放入同一个经验风险目标：

$$\min_{\theta, \psi} \frac{1}{n} \sum_{i=1}^n \ell(g_{\psi}(\mathbf{r}_{\theta}(\mathbf{x}_i)), y_i). \quad (7.5)$$

两部分参数共同受最终任务的损失约束。这种**端到端学习**（end-to-end learning）把从输入到输出的一整条计算路径纳入同一学习目标。它仍需确定输入编码、网络结构和损失；对于不可微的操作，也需要另外设计参数更新方法。隐藏层能够表达有用特征、算法能够找到这些特征、得到的预测能用于新样本，是三个不同问题。

7.1.2 分布式表示与层次表示

一个隐藏向量有多个坐标，信息可以怎样放进这些坐标？如果每种对象只激活一个专属坐标，表示的区分主要由“哪一个坐标被激活”完成。**分布式表示**（distributed representation）采用另一种组织方式：一个对象由多个单元的活动共同表示，而同一个单元又可以参与多个对象的表示。这里

的“分布式”指信息分布在若干坐标中，与把计算分配到多台机器是不同的概念。

一个简化例子是同时记录物体的颜色、形状和大小。若三个二值坐标分别表示“红色”“圆形”“较大”，那么 $(1, 1, 0)$ 表示一个较小的红色圆形物体， $(1, 0, 0)$ 表示一个较小的红色非圆形物体。两个对象共享部分坐标，又在形状坐标上不同。三个二值坐标可以组成八种不同编码，说明共享属性能够通过组合区分对象；这只是编码数量的计算，不能据此推出模型用少量样本就一定能学会所有组合。

真实网络的坐标通常是连续数值，也未必逐一对应“颜色”这样的命名属性。表示中的信息可能需要若干坐标共同参与后续计算才能被读取。因而，某个单元响应某类输入，并不自动证明它只表示一个概念；分布式表示也可以是稀疏的，只要一个对象仍由若干可复用单元共同编码。这种对信息组织方式的理解，比把每个单元固定解释成一个符号更适合描述许多网络表示¹。

分布式表示考察同一层内的信息怎样分配，**层次表示** (hierarchical representation) 则考察不同层之间怎样组合信息：后层利用前层的表示继续构造新特征。以图像为例，一层可以响应局部明暗变化，后层再组合这些响应以识别纹理或形状。这里的“局部变化—组合模式”是理解层次结构的一条路径，不是所有网络必须遵循的固定语义顺序。层数越多，也不保证每一层的含义越抽象或越容易解释。

两种表示方式可以同时存在。一个层用多个单元共同表达某种形状，下一层再把这组活动与其他信息组合。图 7.3 强调的正是这种计算关系：每层提供一组供后续使用的数值，最终预测又通过学习目标影响各层参数。表示是否有用，要结合后续任务判断；为了分类而压缩的区别，在重建输入时可能仍然需要保留。




图 7.3 表示学习的一条计算路径。实线表示输入经过两层变换后交给输出映射，虚线表示从训练目标返回的梯度或监督信号；它约束表示层与输出层的参数，但不是普通前向数据流。图只展示层间依赖，不要求隐藏坐标具有预先指定的语义。

¹ I. Goodfellow, Y. Bengio, A. Courville, *Deep Learning*, MIT Press, 2016

7.1.3 结构带来的归纳偏置

允许学习表示，并没有规定所有输入都应怎样相互联系。若把图像中的每个像素与下一层所有单元相连，模型可以使用任意位置的组合，却没有直接体现相邻像素往往共同形成局部模式这一特点。网络结构可以预先限定哪些信息被组合、哪些计算被重复使用，从而影响学习时优先考虑的规律。

这种预先的限制或偏好称为**归纳偏置**（inductive bias）：面对有限数据，学习方法依据哪些假设把已经看到的关系推广到未见输入。偏置可以来自结构，也可以来自参数约束、损失和学习算法。这里聚焦结构，考察它怎样改变候选函数与信息传递路径。

局部连接（local connectivity）让一个单元只读取某个邻域的信息，例如图像中的一小块像素。**参数共享**（parameter sharing）让多个位置重复使用同一组参数，例如把同一个局部模式检测器移到图像各处。这两项设计分别规定“看哪些输入”和“在哪些位置使用同一种计算”。它们可以减少独立参数的数量，并使不同位置的数据共同参与共享参数的学习；具体效果仍取决于数据是否具有相应的局部性和重复规律。

对序列而言，结构还可以保留**隐状态**（hidden state），即在处理当前输入时保存一组由历史输入计算得到的数值。下一步继续读取这组数值，就能利用此前的信息。例如，看到“虽然”之后，后续判断可能需要继续保留尚未完成的转折关系。状态的存在提供了记忆通道，但状态维度、更新方式和学习过程仍会限制实际能够保留的信息。

结构假设匹配数据时，学习算法无需为每个位置或时间步单独发现同一种关系。假设不匹配时，同样的限制也可能排除需要的函数：只允许狭小邻域交互，可能难以直接比较相隔很远的对象；强制不同位置使用同一参数，可能忽略位置本身的特殊意义。网络设计需要在表达能力、样本利用与计算成本之间作出取舍。第二卷“基础、理论和可信性”的“深度学习的可学习性”章已经说明，架构允许哪些函数与训练算法选出哪个函数分别影响学习结果，不能从结构名称直接得到泛化保证。

7.2 生物神经网络

人工网络为什么借用“神经元”“连接”和“学习”这些名称？理解它们的来源，需要同时看细胞怎样通信、系统怎样组织信息，以及经验怎样改变连接。本节从这三个方面介绍生物神经网络，再比较人工网络保留了哪些计算思想、哪些细节需要另外建模。




图 7.4 三个神经元在同一幅画面中通过突触相连。细线标出树突、胞体、细胞核、轴突、髓鞘、郎飞结与轴突末梢；蓝色箭头概括神经元 1 的轴突分成两支，分别经突触 1 和突触 2 影响神经元 2 和神经元 3 的方向，金黄色末梢表示突触前端。突触处的微小间隙只作概念提示。图展示一种多极、有髓鞘的神经元形态，各部分不按比例；真实神经元形态多样，部分轴突没有髓鞘，回路也可以包含反馈和更多连接。

7.2.1 神经元

生物**神经元** (neuron) 是接收和传递信号的细胞。许多神经元通过树突和胞体接收输入，**膜电位** (membrane potential)，也就是细胞膜内外的电势差，随输入和细胞内部动态变化。在适当条件下，神经元产生称为**动作电位** (action potential) 的短暂电信号，通常也称脉冲，并沿轴突影响其他细胞。神经元之间传递影响的连接部位称为**突触** (synapse)，其传递效果可以随活动发生变化。这里概括的是典型脉冲神经元的部分机制，不覆盖所有细胞类型和信号传递方式。

图 7.4 用一个神经元连接另外两个神经元的回路，把接收与传递信号的结构展开。树突从胞体向外分支，提供与其他细胞发生交互的部位；轴突则把信号传到末梢，末梢可以与其他细胞形成突触。支持神经元活动的**胶质细胞** (glial cell) 参与维持细胞环境和形成髓鞘等过程。部分轴突外包有**髓鞘** (myelin sheath)，即胶质细胞形成的多层膜结构，有助于加快传导。相邻髓鞘段之间的间隙称为**郎飞结** (node of Ranvier)，动作电位在这些位置再生。在脑中，髓鞘由少突胶质细胞形成；神经元的形态各异，也并非所有轴突都有髓鞘²。

信号到达末梢后，怎样影响下一个细胞？在常见的**化学突触** (chemical

² D. Purves, G. J. Augustine, D. Fitzpatrick, L. C. Katz, A.-S. LaMantia, J. O. McNamara, S. M. Williams, eds. *Neuroscience*, Sinauer Associates, 2001, 2nd ed.

synapse) 中, 动作电位促使末梢释放**神经递质** (neurotransmitter), 即传递影响的化学信号分子。递质穿过两细胞之间的狭小间隙, 与接收侧的受体作用, 进而改变离子通道活动和膜电位。输入的作用可以是促进, 也可以是抑制脉冲发放, 具体取决于受体、通道与细胞状态。**电突触** (electrical synapse) 则通过连接两细胞的通道直接传递电流。因此, 图中的连接不能统一理解成把一个数值无延迟地送给下一个单元的导线³。

接收到一次输入, 并不意味着细胞必然发放一次脉冲。突触输入引起的膜电位变化会持续一段时间, 再逐渐衰减; 若其他输入在这段时间内到达, 它们的影响就可能共同改变细胞的响应。来自多个连接的输入与同一连接在不同时间到达的输入, 都可以参与这种整合, 抑制性输入又可能降低发放的机会。在简化模型中, 可以把较弱输入的影响近似相加, 并用阈值描述何时发放; 真实细胞的整合还取决于树突位置、膜上的通道和近期活动, 未必只是一个静态加权和⁴。

脉冲的个数与发生时刻都可以参与信息表达。例如, 同样发放 3 次脉冲, 集中在短时间内与分散在较长时间内, 对接收细胞可能产生不同影响; 单个细胞的活动又需要放在其他细胞的共同活动中理解。许多典型动作电位持续约 1 至 2 ms, 这是细胞信号的时间尺度, 不能直接当作大脑完成一个判断所需的时间。判断可能依赖多个回路中的持续活动与往返交互⁵。

7.2.2 神经系统

单个细胞的接收和发放机制, 还不能解释视觉、记忆或动作怎样形成。神经元连接成局部回路, 多个回路再参与更大范围的神经系统。按解剖位置, 人类神经系统通常分为脑与脊髓组成的**中枢神经系统** (central nervous system, CNS), 以及联系中枢与身体其他部分的**外周神经系统** (peripheral nervous system, PNS)。感觉输入、内部活动和动作输出通过这些系统相互联系; 下面主要考察人脑, 尤其是与人工视觉模型联系较紧密的大脑皮层⁶。

先看这种启发来自多大规模的系统。Azevedo 等在 2009 年分析了 4 个年龄为 50 至 71 岁的成年男性脑样本, 估计神经元数量的样本均值约为 861 亿, 样本标准差约为 81 亿。这是常用的“人脑约有 860 亿个神经元”说法的一项主要依据。研究通过细胞核计数与神经元标记估算数量; 这个结果应当用于理解规模, 不能当作每个人都有同样数量的精确常数。同一研究中, 大脑皮层约有 163 亿个神经元, 小脑约有 690 亿个, 分别约占总数的 19% 和 80%。神经元数量在不同结构间很不均匀, 数量最多的结构也不能仅凭这一点被认定为负责所有最复杂的认知任务⁷。

这些细胞并非排成一组统一的层。脑内既有形成局部回路的连接, 也有联系不同区域的长距离通路; 大脑皮层、小脑和脑干等结构具有不同的细胞组织与连接方式。神经元与胶质细胞共同构成脑组织, 后者还参与代谢

³ D. Purves, G. J. Augustine, D. Fitzpatrick, L. C. Katz, A.-S. LaMantia, J. O. McNamara, S. M. Williams, eds. *Neuroscience*, Sinauer Associates, 2001, 2nd ed.

⁴ W. Gerstner, W. M. Kistler, R. Naud, L. Paninski, *Neuronal Dynamics: From Single Neurons to Networks and Models of Cognition*, Cambridge University Press, 2014, 1st ed.

⁵ W. Gerstner, W. M. Kistler, R. Naud, L. Paninski, *Neuronal Dynamics: From Single Neurons to Networks and Models of Cognition*, Cambridge University Press, 2014, 1st ed.

⁶ D. Purves, G. J. Augustine, D. Fitzpatrick, L. C. Katz, A.-S. LaMantia, J. O. McNamara, S. M. Williams, eds. *Neuroscience*, Sinauer Associates, 2001, 2nd ed.

⁷ F. A. C. Azevedo, L. R. B. Carvalho, L. T. Grinberg, J. M. Farfel, R. E. L. Ferretti, R. E. P. Leite, W. Jacob Filho, R. Lent, S. Herculano-Houzel, *Equal Numbers of Neuronal and Nonneuronal Cells Make the Human Brain an Isometrically Scaled-Up Primate Brain* In The Journal of Comparative Neurology, 2009, vol. 513, no. 5, pp. 532–541

支持等过程。因而，理解脑的架构，需要同时考察细胞类型、局部回路与区域间通信，不能只数计算单元⁸。

脑的计算能力需要从这些网络的活动来理解。大量细胞可以同时接收输入和改变状态，计算分散在许多局部回路中；反馈连接又使当前响应依赖过去的活动。即使没有新的外部任务，脑内仍有持续的活动。并行性、内部状态与信号往返让脑能够处理随时间变化的感觉和行为信息，但这些特点本身不能给出某项任务的准确率，也不能由细胞数量推出每秒完成多少次通用算术运算。

维持这种活动还需要能量。成人脑的质量约占体重的2%，却消耗全身约20%的氧和相应代谢能量⁹。描述成人脑时，约20W这一量级常用于表示葡萄糖供能对应的代谢功率；它包含通信与维持细胞功能等支出，各过程如何分摊能量还依赖具体的估算模型¹⁰。这说明信息传递和维持活动也是计算系统的成本。若要与人工系统比较效率，需要固定任务、准确率、响应时间和能耗范围；把一次突触事件直接算作一次浮点运算，会忽略两者操作内容和精度的差异，得不到统一的“大脑算力”。

这些局部回路和长距离连接在皮层中怎样组织？**大脑皮层**（cerebral cortex）是覆盖大脑半球表面的薄层组织，折叠形成沟和回。皮层属于**灰质**（gray matter），其中集中着细胞体、树突、突触与局部轴突；皮层下的**白质**（white matter）以轴突束为主要组成，为区域间通信提供通路。两种名称概括组织组成，并不是把脑机械分成“只计算”和“只传输”的两部分¹¹。

人脑大部分皮层属于**新皮层**（neocortex），按细胞密度、形态和连接等特征，通常从表面向内分成I至VI六个解剖层。不同层接收与发出的连接有所不同，层内存在横向联系，层间又有跨层联系。这里的“六层”是同一皮层厚度方向上的组织分层；V1、V2等脑区各自包含自己的层内和层间回路，不能把这六层理解成人工网络连续执行的六个计算步骤¹²。

层内与层间回路还与其他区域相连。以视觉为例，可以观察局部输入怎样经过多个区域，形成识别和行动所需的信息。**中央沟**（central sulcus）是区分数叶与顶叶的主要解剖标志，本身不是视觉计算阶段。图7.5借助中央沟和各叶的位置定位视觉区，箭头表示主要传递方向。

视觉处理从眼中的**视网膜**（retina）开始，光在这里转化为神经信号，并经过局部回路处理。一条主要通路把视网膜神经节细胞的输出经丘脑的**外侧膝状体**（lateral geniculate nucleus, LGN）送到**初级视觉皮层**（primary visual cortex, V1）。V1主要位于枕叶内侧的距状沟周围，单从脑的外侧看不到它的大部分。V1之后的信号经V2等区域继续传递，逐渐进入分布在枕叶、颞叶与顶叶的多个视觉区域。这里描述的是主通路，视觉信号也参与眼动和反射等其他通路¹³。

⁸ D. Purves, G. J. Augustine, D. Fitzpatrick, L. C. Katz, A.-S. LaMantia, J. O. McNamara, S. M. Williams, eds. *Neuroscience*, Sinauer Associates, 2001, 2nd ed.

⁹ M. E. Raichle, D. A. Gusnard, *Appraising the Brain's Energy Budget* In Proceedings of the National Academy of Sciences, 2002, vol. 99, no. 16, pp. 10237–10239

¹⁰ W. B. Levy, V. G. Calvert, *Communication Consumes 35 Times More Energy than Computation in the Human Cortex, but Both Costs Are Needed to Predict Synapse Number* In Proceedings of the National Academy of Sciences, 2021, vol. 118, no. 18, e2008173118

¹¹ D. Purves, G. J. Augustine, D. Fitzpatrick, L. C. Katz, A.-S. LaMantia, J. O. McNamara, S. M. Williams, eds. *Neuroscience*, Sinauer Associates, 2001, 2nd ed.

¹² D. Purves, G. J. Augustine, D. Fitzpatrick, L. C. Katz, A.-S. LaMantia, J. O. McNamara, S. M. Williams, eds. *Neuroscience*, Sinauer Associates, 2001, 2nd ed.

¹³ D. Purves, G. J. Augustine, D. Fitzpatrick, L. C. Katz, A.-S. LaMantia, J. O. McNamara, S. M. Williams, eds. *Neuroscience*, Sinauer Associates, 2001, 2nd ed.




图 7.5 人脑视觉区域的位置与两条主要通路。自然解剖插画上的点位是教学定位，外侧图显示中央沟、顶叶皮层、MT (V5)、V3 背侧部分，以及 V4 / hV4 和下颞皮层 IT 的概略位置；内侧图标出距状沟附近的 V1。外侧图中的 V1、V2 和腹侧区域采用位置投影。红色实线表示经 V4 等区域向 IT 传递的内容通路 what，蓝色虚线表示经 MT、背侧视觉区向顶叶传递的空间通路 where；右下角用微型路径图抽去解剖背景后重述这一区别。点位与箭头依据视觉区研究和通路概括绘制，不表示精确边界、完整连接或唯一串行顺序；跨通路联系与反馈未画全。

图中的区域名并非一张“每区只负责一个属性”的清单。V3 是早期视觉区域之一，含有背侧与腹侧部分；V4 及人脑常用的 hV4 名称关联于腹侧视觉区，其中的响应涉及颜色与形状等信息。MT 也常称 V5，运动相关响应是识别它的一项重要线索；人脑成像中的 hMT+ 还可以包括邻近的运动相关区域，不能把这些名称当作边界完全相同的单一区域。**下颞皮层** (inferotemporal cortex, IT) 指下部颞叶的一组视觉相关皮层，是理解物体识别通路的区域性称谓。人脑与其他灵长类的视觉区域在命名和边界上存在差别，图中保留 V4、MT、IT 等常见名称用于讲解，不声称它们在所有物种中逐一相同¹⁴。

区域间的联系通常概括为两条主要通路。**腹侧视觉通路** (ventral visual stream) 从早期视觉区向 V4 等区域以及下颞皮层传递信息，偏重颜色、形状与物体身份，因此常称**内容通路** (what pathway)，即帮助判断“看到的是什”。**背侧视觉通路** (dorsal visual stream) 联系 MT、其他背侧视觉区与后部顶叶皮层，偏重运动、空间关系和视觉引导的动作，常称**空间通路** (where pathway)。例如，看到一个杯子时，识别它是杯子与确定伸手抓取时的位置、方向和手形，需要利用不同但相互配合的信息。where 并

¹⁴ B. A. Wandell, S. O. Dumoulin, A. A. Brewer, *Visual Field Maps in Human Cortex* In *Neuron*, 2007, vol. 56, no. 2, pp. 366–383

不只表示报告静态坐标，也包含如何根据视觉控制动作；两条通路之间还会交换信息¹⁵。

这些区域为何适合启发层次模型，还要回到单元响应。一个视觉神经元通常只对视野中某个范围内的刺激产生相应变化，这个范围称为**感受野** (receptive field)。感受野说明“哪些位置的输入能影响该单元”，单元的响应偏好则说明“这些位置上出现什么模式时响应更强”。Hubel 和 Wiesel 在猫的视觉皮层中研究了对特定取向的光条或边缘敏感的细胞，并区分简单细胞与复杂细胞的感受野特征。简单细胞对亮暗位置的安排具有较明确的选择性，一些复杂细胞则能在一定位置范围内对相近取向的刺激作出响应。这些实验为局部响应及其组合提供了生物学依据；实验对象是猫，不能把全部细节直接当作人脑的逐层结构¹⁶。

局部响应经过后续回路组合，可以对更大范围、更复杂的模式产生选择性：早期视觉区中的取向信息与后续区域中的形状、物体相关响应，共同提供了理解**层次特征** (hierarchical feature) 的生物学线索，即利用已有特征继续形成新的特征。这里的层次跨越多个回路和区域，与皮层的六个解剖层属于不同概念。视觉连接还包含反馈和并行通路，因此“局部边缘—形状—物体”适合作为理解线索，不能当作大脑必须逐步执行且只执行一次的流程¹⁷。

7.2.3 生物学习

视觉回路能够组合已有响应，但经验还需要改变以后面对输入时的响应。短暂的膜电位变化描述细胞当前的状态；较持久的连接变化则能改变后续输入产生的影响。**突触可塑性** (synaptic plasticity) 指突触传递效果能够随活动等因素改变，是研究生物学习的一类重要机制。

先看只依赖连接两端活动的简化规则。用标量 w_j 概括第 j 条连接的强度，用 u_j 和 h 分别概括输入端与输出端的活动，一个相关性更新例子是

$$\Delta w_j = \eta u_j h, \quad (7.6)$$

其中 Δw_j 是连接强度的改变量， $\eta > 0$ 控制更新幅度。这个式子展示一种**赫布学习** (Hebbian learning) 思路：共同活动影响连接强度。它是便于比较的信息依赖示例，没有脉冲时序、权重限制和整体任务误差，不能当作完整生物学习机制；若持续出现正相关活动而没有其他约束，权重还可能不断增大。

相关活动还可以细分为发放的时间关系。**脉冲时序依赖可塑性** (spike-timing-dependent plasticity, STDP) 描述突触变化对两端脉冲相对时刻的依赖。Bi 和 Poo 在培养的海马神经元中观察到，特定配对条件下，突触变化与脉冲先后关系有关；该结果描述的是相应细胞和实验条件，不能直接

¹⁵ M. A. Goodale, A. D. Milner, *Separate Visual Pathways for Perception and Action* In Trends in Neurosciences, 1992, vol. 15, no. 1, pp. 20–25

¹⁶ D. H. Hubel, T. N. Wiesel, *Receptive Fields, Binocular Interaction and Functional Architecture in the Cat's Visual Cortex* In The Journal of Physiology, 1962, vol. 160, no. 1, pp. 106–154

¹⁷ D. Purves, G. J. Augustine, D. Fitzpatrick, L. C. Katz, A.-S. LaMantia, J. O. McNamara, S. M. Williams, eds. *Neuroscience*, Sinauer Associates, 2001, 2nd ed.

扩成所有突触的统一规则¹⁸。

局部相关性还没有解决“怎样改变连接才能改善行为”这个问题。例如，伸手抓取杯子时动作出现偏差，需要把行为结果与参与感觉和动作的多个回路联系起来。这种**信用分配**（credit assignment）问题关心整体结果的好坏应怎样影响内部各个环节。仅仅知道两端曾经共同活动，并不足以确定这条连接对行为偏差的贡献。生物可塑性还受到反馈和调节信号的影响，局部变化如何与整体目标联系，仍是研究的重要问题¹⁹。

7.2.4 与人工神经网络的对比

生物细胞、回路和可塑性为人工模型提供了不同层次的启发。比较时需要明确当前关注的是输入与输出的函数关系、信号的时间动态，还是学习规则；同一个模型可以在某一方面相似，在另一面采用工程上的简化。

人工计算单元保留了“多个输入共同影响输出”这一抽象。若输入为 $\mathbf{u} \in \mathbb{R}^d$ ，单元可以写为

$$a = \sum_{j=1}^d w_j u_j + b, \quad h = \sigma(a), \quad (7.7)$$

其中 w_j 描述第 j 项输入对加权和 a 的影响， b 调整响应的位置， σ 把 a 映射为输出 h 。权重对应的是连接影响强弱的数学抽象，激活函数对应的是输入与输出之间的响应关系；二者都没有完整描述突触化学过程或细胞电生理。

图 7.6 把人工单元的运算展开：每项输入乘以相应权重，所有贡献与偏置相加，再经过激活函数。这种画法便于逐项核对式(7.7)，却已经省略了图 7.4 中的细胞形态与化学过程。该式也没有内部时间状态，因此仅凭当前 $\mathbf{u}$ 就能计算 h ；一个真实细胞的响应还可能依赖此前的膜电位、近期活动和其他调节因素。这一差别决定了普通单元适合哪种抽象，也为后文保留时间动态的脉冲模型留下了空间。

多个单元连接起来，比较的对象便从细胞变为网络。图 7.7 左侧用局部回路与跨区域连接表示生物组织的一些特点，右侧则给出一个明确的层状前馈计算。右图的中间输出按约定次序计算，左图所示回路则可以让此前活动再次影响后续响应。人工网络也可以加入反馈、状态和不同单元类型；二者的区别需要落实到具体结构与动态，而不能只看图上都有节点和连线。一个生物神经元可以具有复杂的树突计算，一个人工单元也可以被设计成复杂函数，因此神经元数、人工单元数与参数量不能直接互换。

¹⁸ G.-q. Bi, M.-m. Poo, *Synaptic Modifications in Cultured Hippocampal Neurons: Dependence on Spike Timing, Synaptic Strength, and Postsynaptic Cell Type* In The Journal of Neuroscience, 1998, vol. 18, no. 24, pp. 10464–10472

¹⁹ T. P. Lillicrap, A. Santoro, L. Marris, C. J. Akerman, G. Hinton, *Backpropagation and the Brain* In Nature Reviews Neuroscience, 2020, vol. 21, no. 6, pp. 335–346





图 7.6 人工神经元的计算示意。标有 w_j 的输入边表示乘以权重，求和节点再加入偏置 b ，激活函数产生输出 h 。接收输入、整合影响与产生输出，是它与生物神经元之间的功能对应；图中的数学运算不完整复现细胞机制。

生物神经网络的局部示意



前馈人工神经网络




图 7.7 从单元到网络的两种组织示意。左侧用轮廓不同的节点表示细胞类型差异，淡色区域表示局部群体，箭头同时包含局部回路与跨群体联系；它是教学构造，并非测得的人脑连接图。右侧是一个前馈人工网络，箭头表示输入、中间表示与输出之间的计算依赖。图中的节点数量不表示真实规模，右图也不涵盖人工网络的所有结构。

前面介绍的视觉感受野与层次响应,带来了一个人工视觉模型的设计问题:能否在不同位置检测局部模式,再把这些检测结果组合成更大范围的表示? Fukushima 在 1980 年提出的**新认知机**(neocognitron)受这种层次思路启发,交替组织检测局部模式的 S 单元与汇集响应的 C 单元,以获得对位置变化具有一定容忍度的识别表示。这是从视觉机制走向人工层次结构的一项早期工作,其自组织学习方法也与后来的监督梯度训练不同²⁰。

卷积神经网络沿用的核心设计包括局部感受野、重复使用局部检测方式,以及逐层扩大信息组合范围。局部连接限制一个单元读取的输入区域;参数共享则把同一个检测函数用于不同位置。后者是明确的工程约束,不能从“许多生物细胞具有相似响应偏好”推出它们精确共享同一组突触参数。网络还可以采用**池化**(pooling),即汇总邻域内的若干响应,以降低表示的空间分辨率或减小对局部位移的敏感性。卷积、非线性响应与邻域汇总组合后,后层能够读取较大范围内的局部特征组合。

这些联系说明了卷积网络为什么适合从局部结构构造视觉表示,并不要求某个卷积层恰好对应 V1、下一个层对应 V2。what 与 where 也区分了表示服务的目标:物体识别希望在位置变化后仍保留身份判断,定位和动作控制却需要保留空间关系,不能一概消除位置信息。后面的卷积神经网络章将把感受野、参数共享、池化以及平移等变与不变的条件写成明确运算;这里的生物学关联为这些设计提供动机,其性质仍需由具体计算和证据来判断。

脉冲神经网络(spiking neural network, SNN)把单元之间传递的信号表示为离散脉冲事件,并通常保留随时间演化的内部状态。它既可用于研究神经系统,也可用于任务预测和事件驱动计算;连接结构、单元动态和参数学习规则还需要分别设计。

脉冲模型可以用输入改变膜电位、达到阈值时发放并重置状态等规则,保留“积累—发放”的时间过程;普通连续值单元则常直接计算当前输入对应的数值。这样的差别使 SNN 更适合表达某些脉冲时刻相关的问题,但脉冲编码不自动补齐树突形态、递质作用、胶质支持或生物可塑性。卷积与脉冲也不是互斥的网络类别:前者规定局部连接和参数共享,后者规定信号形式与时间动态,因而可以构造采用脉冲单元的卷积网络²¹。

学习机制与信用分配 在单元形式之外,更深的差别是怎样从经验中改变连接。常见的人工网络训练直接规定一个整体损失,并利用该损失对各参数的导数更新参数。对于式(7.7),设当前可微损失 $\mathcal{L}$ 通过输出 h 依赖权重 w_j , 则

$$\frac{\partial \mathcal{L}}{\partial w_j} = \frac{\partial \mathcal{L}}{\partial h} \sigma'(a) u_j. \quad (7.8)$$

²⁰ K. Fukushima, *Neocognitron: A Self-Organizing Neural Network Model for a Mechanism of Pattern Recognition Unaffected by Shift in Position* In *Biological Cybernetics*, 1980, vol. 36, no. 4, pp. 193–202

²¹ W. Gerstner, W. M. Kistler, R. Naud, L. Paninski, *Neuronal Dynamics: From Single Neurons to Networks and Models of Cognition*, Cambridge University Press, 2014, 1st ed.

输入 u_j 和局部导数 $\sigma'(a)$ 只描述这个单元附近的计算； $\partial \mathcal{L} / \partial h$ 还包含 h 通过后续网络影响损失的信息。**误差反向传播** (error backpropagation) 从输出端出发，沿计算依赖反向应用链式法则，组织这些导数的计算。它提供梯度；用梯度怎样修改参数，是优化算法的工作。若激活函数在某点不可微，则需另行约定该点的处理方式。

两类学习的共同点，是经验能够改变连接的影响，进而改变下一次输入引起的响应。生物突触的传递效果与人工权重都承担了这种作用，许多连接的变化共同影响网络的行为。这里还需要区分当前活动与连接学习：一次脉冲或一次前向计算改变当前活动，连接学习则改变突触传递效果或模型参数。内部状态也可以保存信息，但状态变化与连接更新是不同的对象。这个对应解释了为什么人工网络可以借鉴可塑性，却没有规定两者必须使用同一种更新规则。

生物学习的重要基础是局部突触可塑性。通常所说的**赫布定律** (Hebb's rule) 强调：一个神经元的活动反复参与另一个神经元的发放，两者之间的连接可能增强。式(7.6)展示的是这种思想的简化形式。不过，大脑的学习不能只写成“两端同时活动就增强连接”。脉冲时序、细胞状态与调节信号都会影响变化；一些研究还考察局部活动能否先留下短暂的突触痕迹，待奖励等信号到来时再改变连接。这使局部活动能够与稍后出现的行为结果联系起来，仍不等于逐条计算整体损失的精确梯度²²。

最关键的不同点，是更新依据什么信号，以及这个信号怎样到达内部连接。标准反向传播把一个明确的任务损失作为共同依据：式(7.8)中的 $\partial \mathcal{L} / \partial h$ 衡量隐藏输出如何影响最终损失，后续计算的导数又把这一影响传回当前单元。因此，即使两条连接附近的活动相似，只要它们对任务误差的贡献不同，得到的梯度也可以不同。式(7.6)仅使用两端活动，STDP 则进一步利用脉冲的相对时刻；这些局部量本身没有给出最终任务损失的精确导数。用“活动相关”决定变化，与用“对任务误差的影响”决定变化，是本节两种更新示例最需要区分的地方。

学习信号的实现方式也不同。在常见的软件实现中，人工网络沿已知计算图反向求导，并在数值存储中更新参数；生物突触的变化由细胞内过程实现，能够使用的活动、时序及反馈信号受实际连接和动态限制。**目前不能把大脑的学习机制等同于标准反向传播，也不能用单一赫布规则概括全部生物学习。**大脑存在广泛反馈，研究仍需解释这些反馈怎样帮助信用分配。Lillicrap 等讨论了利用反馈引起的活动变化近似误差信号的可能机制；这是关于可能实现方式的探索，尚不构成大脑执行标准反向传播的证据²³。

上述差异针对本节比较的局部可塑性与标准反向传播，不是生物和人工系统的绝对分界。人工网络也可以采用局部相关性更新，脉冲网络也可以按任务损失训练。采用哪种编码、怎样连接单元、怎样学习参数，是需

²² W. Gerstner, M. Lehmann, V. Liakoni, D. Corneil, J. Brea, *Eligibility Traces and Plasticity on Behavioral Time Scales: Experimental Support of NeoHebbian Three-Factor Learning Rules* In *Frontiers in Neural Circuits*, 2018, vol. 12, 53

²³ T. P. Lillicrap, A. Santoro, L. Marris, C. J. Akerman, G. Hinton, *Backpropagation and the Brain* In *Nature Reviews Neuroscience*, 2020, vol. 21, no. 6, pp. 335–346

要分别说明的设计选择。

信息流动与自上而下的预测 学习规则不同，还要与感知时的信息流区分开。在一个普通前馈分类器中，输入经过各层产生输出，一次预测不需要把高层结果再送回低层。人脑的视觉系统则同时存在自下而上的感觉输入和自上而下的反馈，当前理解会反过来影响对输入的处理。Bar 等的研究支持一种具体假说：图像的粗略信息较快到达额叶中的眶额皮层，由这里形成可能的物体解释，再帮助颞叶视觉区域识别输入。研究观察到识别相关的眶额活动早于相应颞叶活动，这为预测参与视觉识别提供了依据；不能据此把所有预测都归结为额叶一个区域²⁴。

面对模糊物体时，已有经验可以帮助形成候选解释，再与当前感觉证据相互校正。日常所说的“脑补”可以从这种补全缺失信息的过程理解；预测可能帮助识别，也可能使错误预期干扰判断。**感知中的反馈传递神经活动，反向传播计算训练所需的导数，两者是不同过程。**人工网络也能加入循环、反馈或反复推断，因此“人工信息流只有前向”只适用于这里比较的前馈结构，不能概括全部人工架构。

少样本学习与知识迁移 人往往能利用少量新例子理解与已有经验相关的概念。例如，已经熟悉书写的人看到一个陌生字符，可以利用笔画、连接和书写方式来判断它的其他写法。Lake 等以手写字符为对象研究单样本概念学习，并构造了能够组合和复用笔画等知识的程序模型；模型在相应任务上达到与人类相近的表现。这项结果说明，少量新样本可以与丰富的已有知识共同支持泛化，而不是证明人脑在毫无先前经验时也能学会任意任务²⁵。

相比之下，从随机参数开始、针对固定类别训练的监督网络，常需要较多带标签样本才能形成相应表示；它不能自动获得人已积累的概念与经验。人工网络也可以通过迁移学习复用表示，或通过元学习练习如何用少量数据适应新任务，前文的字符学习例子已说明这种组织方式²⁶。比较样本效率时，需要同时记录新任务用了多少样本，以及此前用了多少数据、任务和其他知识。人类的快速迁移是人工学习的重要参照，但新知识与旧知识的联系越弱，就越不能假定只需少量练习。

鲁棒性与对抗扰动 在熟悉对象的识别中，人可以容忍一定程度的模糊、遮挡和背景变化。不过，普通图像上的高准确率并不保证人工网络也具有同样的感知稳定性。Szegedy 等发现，针对网络寻找的细小图像扰动，可以在视觉上几乎不改变图像时使模型误分类²⁷。例如，可以出现人仍把图像看作一个杯子，分类器却输出另一类别的情形。这里的扰动经过有意搜索，与随意加入一点随机噪声不同；它暴露了模型的分类依据与人的判断之间的差距。

²⁴ M. Bar, K. S. Kassam, A. S. Ghuman, J. Boshyan, A. M. Schmid, A. M. Schmidt, A. M. Dale, M. S. Hämäläinen, K. Marinkovic, D. L. Schacter, B. R. Rosen, E. Halgren, *Top-down Facilitation of Visual Recognition* In Proceedings of the National Academy of Sciences, 2006, vol. 103, no. 2, pp. 449–454

²⁵ B. M. Lake, R. Salakhutdinov, J. B. Tenenbaum, *Human-level Concept Learning through Probabilistic Program Induction* In Science, 2015, vol. 350, no. 6266, pp. 1332–1338

²⁶ C. Finn, P. Abbeel, S. Levine, *Model-Agnostic Meta-Learning for Fast Adaptation of Deep Networks* In Proceedings of the 34th International Conference on Machine Learning, 2017, pp. 1126–1135

²⁷ C. Szegedy, W. Zaremba, I. Sutskever, J. Bruna, D. Erhan, I. Goodfellow, R. Fergus, *Intriguing Properties of Neural Networks* In arXiv preprint arXiv:1312.6199, 2014

人眼不易察觉的扰动能使某些模型出错，不等于人脑对所有对抗攻击都免疫。Elsayed 等发现，在限制观察时间的实验条件下，一些针对计算机视觉系统构造的扰动也会影响人的分类²⁸。人类还会受到错误预期和跨感官冲突的影响。因此，比较鲁棒性应固定任务、扰动范围、观察时间和评价指标；人工网络的稳健训练也会改变结果。第二卷“基础、理论和可信性”的“鲁棒性”章已经说明，普通噪声、自然分布变化与主动寻找的最不利扰动需要分别评价。

计算活动的能量成本 人脑在约 20 W 量级的代谢功率下，持续维持感觉、行动和内部活动，这种丰富功能与较低功率并存的现象构成了人工计算的重要参照。这个数字包含通信和维持细胞功能等成本，不能只算作“有用运算”的功率；脑内的信息传递本身也需要能量²⁹。典型数字实现中的人工网络则要执行数值运算，并在存储与计算部件之间读取权重和中间结果。模型大小、计算精度、活动是否稀疏以及数据搬运方式，都会影响实际能耗。

生物回路中的稀疏脉冲活动和局部连接为减少不必要的计算和通信提供了设计线索，但采用脉冲模型并不自动保证节能。比较时还要区分功率与能量：同样的功率，运行时间越长，总能量越多。因而，不能用整个人脑的代谢功率直接对比某块设备的额定功率，就得到每次判断的能效倍数；应固定任务与准确率，并计入响应时间、学习成本以及所测系统的范围。

多感官输入与联合处理 听别人说话时，声波和说话者的口形同时提供线索。人脑可以联合处理这些输入，而不是等视觉和听觉各自给出最终答案后才简单拼接。这种**多模态处理**（multimodal processing）利用不同类型的信息通道共同理解同一事件。McGurk 和 MacDonald 的经典实验表明，把一种音节的语音与另一种音节的口形配在一起，会使一些人报告听到第三种音节，说明视觉信息能够改变语音感知，而不只是给听觉附加一条独立说明³⁰。

神经系统本身具有多种感觉通道及跨通道联系，具体整合能力仍会随发育和经验形成，不能把所有跨感官关联都理解为出生时已经成熟³¹。许多人工模型只为一种输入类型设计，需要另外建立不同输入之间的联系；人工网络也能学习多模态表示。例如，图像与文本的联合训练可以把描述和图像关联起来³²。这里的差别在于系统能够利用哪些输入、哪些关联来自结构或经验，以及训练是否建立了这些关联，并非人工网络原则上只能处理单一模态。

应当保留多少生物细节，取决于模型要回答什么问题。面向预测的人工网络主要用任务表现评价，不必让每个模块对应真实脑区。解释神经系统的模型则要对特定观察：研究脉冲时间，需要保留影响发放的动态；解

²⁸ G. F. Elsayed, S. Shankar, B. Cheung, N. Papernot, A. Kurakin, I. Goodfellow, J. Sohl-Dickstein, *Adversarial Examples that Fool Both Computer Vision and Time-Limited Humans* In Advances in Neural Information Processing Systems 31, 2018

²⁹ W. B. Levy, V. G. Calvert, *Communication Consumes 35 Times More Energy than Computation in the Human Cortex, but Both Costs Are Needed to Predict Synapse Number* In Proceedings of the National Academy of Sciences, 2021, vol. 118, no. 18, e2008173118

³⁰ H. McGurk, J. MacDonald, *Hearing Lips and Seeing Voices* In Nature, 1976, vol. 264, no. 5588, pp. 746–748

³¹ B. E. Stein, T. R. Stanford, B. A. Rowland, *Development of Multisensory Integration from the Perspective of the Individual Neuron* In Nature Reviews Neuroscience, 2014, vol. 15, no. 8, pp. 520–535

³² A. Radford, J. W. Kim, C. Hallacy, A. Ramesh, G. Goh, S. Agarwal, G. Sastry, A. Askell, P. Mishkin, J. Clark, G. Krueger, I. Sutskever, *Learning Transferable Visual Models from Natural Language Supervision* In Proceedings of the 38th International Conference on Machine Learning, 2021, pp. 8748–8763

释突触变化，需要说明更新规则与实验条件的关系。简化后的结论只能覆盖保留下来的机制，复现某组神经响应也不能单凭这一点确定学习过程相同。

这些方向可以相互借鉴，但预测准确率、生物解释与运行代价是不同的评价标准。在其中一项上有效，不等于另外两项也有证据支持。后续介绍人工架构时，我们将明确其计算假设；涉及生物机制时，再检查所保留的细节与结论范围。

7.3 神经网络的历史

表示、参数学习和计算资源是相互配合的：能够写出一个复杂网络，并不等于知道怎样训练它；有了梯度，也不等于能够在有限资源下处理所需数据。沿着这三个问题考察历史，比只记模型名称和年份更能说明技术变化带来了什么。本节选取与后续架构直接有关的工作，年份指所述论文的发表或首次公开时间。

7.3.1 从阈值单元到可学习网络

1943 年，McCulloch 和 Pitts 用理想化的二值神经元研究神经活动与逻辑计算的关系。单元根据输入和阈值决定是否活动，多个单元连接后可以表达逻辑关系。这项工作建立了用简单单元及其连接描述计算的早期形式化框架，其中心问题是计算如何由网络实现，而不是用现代的训练目标从数据中优化全部参数³³。

当连接权重也允许根据样本改变，研究问题就从“怎样构造计算”延伸到“怎样获得所需计算”。Rosenblatt 在 1958 年的感知机研究中讨论了从经验形成识别行为的网络。前文介绍的基础感知机是这一思路的简化形式：对输入加权求和，按阈值分类，再根据分类错误调整权重。历史上的感知机系统还包含输入与中间组织，不能把原始工作中的所有网络形式都归为今天常用的单层线性分类器³⁴。

基础感知机的限制可以由示例 7.1 直接看出：若输入只有 x_1, x_2 ，调整线性得分的参数无法表示异或。改变输入特征或加入非线性隐藏层，则改变了允许表达的函数。因此，“单层线性分类器不能表示异或”与“神经网络不能表示异或”是不同命题。隐藏层补上了表示能力，接下来还需解决如何根据最终输出学习隐藏层参数的问题。

7.3.2 从浅层学习到深层训练

隐藏层没有直接给定的目标值，难以像输出层那样根据标签判断每个单元应该输出什么。1986 年，Rumelhart、Hinton 和 Williams 展示了通过反向传播误差训练多层网络、形成内部表示的方法。最终目标对隐藏活动的影

³³ W. S. McCulloch, W. Pitts, *A Logical Calculus of the Ideas Immanent in Nervous Activity* In The Bulletin of Mathematical Biophysics, 1943, vol. 5, pp. 115–133

³⁴ F. Rosenblatt, *The Perceptron: A Probabilistic Model for Information Storage and Organization in the Brain* In Psychological Review, 1958, vol. 65, no. 6, pp. 386–408

响可以通过链式法则计算，因而不必为每个隐藏单元人工指定答案。这项工作说明了多层表示怎样参与学习；这里并不把1986年说成链式求导或所有相关算法的首次出现³⁵。

有了参数学习方法，连接结构仍然影响模型怎样利用数据。卷积网络在规则网格上组合局部信息，并在不同位置共享参数；LeCun等1998年的文档识别研究展示了这种结构与基于梯度的整体学习如何结合。手写字符在不同位置出现时，网络可以重复使用已经学习到的局部检测方式，无需为每个位置重新估计一套完全独立的参数³⁶。

对序列，关键问题是怎样利用此前输入。循环结构把历史信息写入状态，再将状态用于下一步计算。但信息与梯度经过许多更新后可能衰减。Hochreiter和Schmidhuber在1997年提出**长短期记忆**（long short-term memory, LSTM），通过记忆路径和可学习的门控制信息的写入与读取。这个名称指一种具体循环网络结构，其目的与机制都涉及跨时间的信息保留，不表示所有长期依赖都会自动被学会³⁷。

深层模型能否发挥作用，还取决于数据规模和计算实现。Krizhevsky、Sutskever和Hinton在2012年的ImageNet分类研究中，结合大规模标注图像、图形处理器上的训练、非线性单元和防止过拟合的训练设计，展示了深层卷积网络的任务表现。这一例子说明，结构、学习方法、数据与计算条件能够共同改变可实现的模型规模；它不能归结为“增加层数就一定提高准确率”³⁸。

这些工作没有形成一条“旧模型被新模型完全取代”的路线。卷积利用空间结构，循环保留序列状态，层次变换构造表示，梯度计算支持参数学习，它们解决的是不同问题，也可以组合使用。后续章节将分别检验各项假设、机制和适用条件。

7.3.3 从固定连接到内容相关计算

局部连接预先规定单元读取哪些位置，固定长度的序列状态则把历史压缩进同一组数值。当当前预测只需要历史中的某一部分时，模型还可以根据当前内容决定读取什么。**注意力机制**（attention mechanism）为候选信息计算相关性权重，再用这些权重组合信息。它改变的是本次计算中各信息来源的影响，而不要求把全局模型参数临时重新训练。

Bahdanau、Cho和Bengio在2014年公开、2015年发表于ICLR的机器翻译研究中，让解码过程按当前需要读取输入序列不同位置的表示。编码器不再只提供一个固定长度的整体概括，而是保留各位置的表示供解码器动态聚合。注意力由此可以与循环网络配合，缓解单一整体表示带来的信息读取限制³⁹。

2017年的**Transformer**架构以注意力为主要信息交互机制，并组合逐位

³⁵ D. E. Rumelhart, G. E. Hinton, R. J. Williams, *Learning representations by back-propagating errors* In Nature, 1986, vol. 323, no. 6088, pp. 533–536

³⁶ Y. LeCun, L. Bottou, Y. Bengio, P. Haffner, *Gradient-Based Learning Applied to Document Recognition* In Proceedings of the IEEE, 1998, vol. 86, no. 11, pp. 2278–2324

³⁷ S. Hochreiter, J. Schmidhuber, *Long Short-Term Memory* In Neural Computation, 1997, vol. 9, no. 8, pp. 1735–1780

³⁸ A. Krizhevsky, I. Sutskever, G. E. Hinton, *ImageNet Classification with Deep Convolutional Neural Networks* In Advances in Neural Information Processing Systems 25, 2012, pp. 1097–1105

³⁹ D. Bahdanau, K. Cho, Y. Bengio, *Neural Machine Translation by Jointly Learning to Align and Translate* In International Conference on Learning Representations, 2015

置变换等模块。在**自注意力** (self-attention) 中, 同一组输入中的各位置根据彼此内容交换信息; 给定一整段已知输入, 许多位置的计算可以并行组织, 不需要像普通循环编码器那样先逐步构造全部状态。生成序列时, 尚未产生的内容仍然不可用, 因此并行训练的计算形式不能直接推出整个生成过程同时完成⁴⁰。

内容相关计算还可以决定使用哪些计算模块。**条件计算** (conditional computation) 根据输入选择本次启用的部分路径; **混合专家** (mixture of experts, MoE) 则用多个子网络共同提供候选变换, 并由路由机制选择或加权组合它们。Shazeer 等 2017 年的稀疏门控工作让每个输入只使用部分专家, 区分了网络存储的总参与与一次输入实际参与计算的参数。路由、负载分配和数据传递也有代价, 不能仅由激活专家少就断定总体运行成本低⁴¹。

另一条路线继续保留状态递推, 同时改进状态的组织与计算。**状态空间模型** (state space model, SSM) 用状态描述此前输入对后续输出的影响。用于序列的神经网络可以把这种更新嵌入可学习模块; 2021 年公开、2022 年发表于 ICLR 的**结构化状态空间序列模型** (structured state space sequence model, S4) 通过特定的状态矩阵组织计算, 在线性、时不变等条件下联系递归更新与卷积计算⁴²。2023 年公开的 Mamba 进一步让部分更新量依赖当前输入, 使状态保留和遗忘具有内容选择性⁴³。

这段发展改变了理解网络时需要观察的对象。除了参数和固定拓扑, 还应考察本次输入决定的注意力权重、所选择的模块, 以及随输入演化的状态。它们都是运行中的计算量或活动, 不必等同于训练后保存的全局参数。状态空间网络与循环网络的联系、自注意力与消息传递的联系, 也说明现代架构的差别需要按具体机制判断。

7.4 神经网络的类型

“卷积”“循环”“图”“注意力”“脉冲”分别强调不同性质。将这些名称并列列出, 容易误以为一个网络只能属于其中一类。本节按连接结构、信息交互方式和信息编码方式分别观察同一个计算对象; 这些分类可以交叉, 也不要求每个完整架构只使用一种机制。

7.4.1 按连接结构划分

连接结构关心计算单元之间的依赖方向与组织方式。**前馈神经网络** (feed-forward neural network) 沿没有有向环的计算依赖, 把输入逐步送到输出; 同一次计算中的中间结果不再返回去修改自己的上游输入。式(7.3)是层状前馈网络, 跨层连接也可以保持前馈性质, 只要计算依赖仍然没有有向环。

⁴⁰ A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, Ł. Kaiser, I. Polosukhin, *Attention Is All You Need* In *Advances in Neural Information Processing Systems* 30, 2017, pp. 5998–6008

⁴¹ N. Shazeer, A. Mirhoseini, K. Maziarz, A. Davis, Q. Le, G. Hinton, J. Dean, *Outrageously Large Neural Networks: The Sparsely-Gated Mixture-of-Experts Layer* In *arXiv preprint arXiv:1701.06538*, 2017

⁴² A. Gu, K. Goel, C. Ré, *Efficiently Modeling Long Sequences with Structured State Spaces* In *International Conference on Learning Representations*, 2022

⁴³ A. Gu, T. Dao, *Mamba: Linear-Time Sequence Modeling with Selective State Spaces* In *arXiv preprint arXiv:2312.00752*, 2023

循环神经网络 (recurrent neural network, RNN) 把此前状态用于下一次更新。同一组更新参数在多个时间步重复使用, 因而既处理当前输入, 也传递历史影响。固定输入序列并按时间展开后, 每一步读取已计算出的前一步状态, 得到的展开计算可以没有有向环; 名称中的“循环”描述的是状态反馈与参数复用, 不是要求在一个时间步中无限反复求值。

例如, 判断一句评论是肯定还是否定, 可以先把整句转为定长向量, 再让前馈网络逐层得到分类得分; 也可以让循环网络逐词读取评论。后一种结构在读到“不”后更新状态, 读到“好”时同时使用当前词和此前状态, 因而提供了保留否定关系的途径。前馈结构传递的是本次计算中已经得到的中间值, 循环结构还显式传递跨时间步的状态; 存在这条状态通道, 并不保证训练后就一定记住了“不”。

依赖也可以沿树组织。**树递归网络** (recursive neural network) 按照树中的父子关系递归地组合表示, 例如用两个子树的表示形成父节点表示。链式状态更新每次通常接收一个前序状态, 树递归则可能组合多个子节点状态, 计算顺序和共享方式因此不同。本书采用广义的循环网络口径, 把链式循环、树递归及基于隐状态递推的状态空间网络放在循环网络章讨论; 它们的具体拓扑仍分别说明。

图神经网络 (graph neural network, GNN) 根据输入图中的实体和关系组织表示计算, 例如让一个节点读取相邻节点的信息。这里必须区分输入图与网络的计算依赖: 输入图可以有环, 模型却可以只执行固定轮数的同步更新, 时间或轮次展开后仍得到有限的计算过程。另一类图网络通过反复状态更新求取某种稳定状态, 两者的学习和计算条件不同。

以预测路口拥堵为例, 输入节点可以是路口, 边表示道路连接。一次同步更新让每个路口读取上一轮的邻居车流表示, 再生成自己的新表示。即使道路形成环路, 这一轮也不用等待邻居先算出同一轮的新值; 按轮次保存旧值与新值, 就能执行有限次更新。

图 7.8 将三个常见依赖模式放在一起。前馈图说明层间先后, 链式展开说明状态的跨时间依赖, 输入图则说明哪些实体有关联。每个神经网络都能用计算图描述, 不意味着每个网络都是图神经网络; 后者的“图”特指模型利用输入的关系结构来组织计算。




图 7.8 三种不同对象的结构示意。左侧是前馈计算中的单元依赖；中间是循环更新的时间展开，三个更新位置共享同一组状态更新参数；右侧显式画出图神经网络的一次邻居聚合，蓝色邻居沿箭头向中心节点 i 提供消息。输入关系可以有环，但一次同步更新的计算依赖仍按层推进。

7.4.2 按信息交互方式划分

确定了大体依赖后，还需说明一次更新怎样组合信息。**全连接**（fully connected）让一组输出中的每个单元读取上一组的全部坐标，常用一个稠密矩阵完成加权组合。**卷积**（convolution）则按规则网格读取局部邻域，并在不同位置重复使用同一组参数。全连接提供广泛的坐标组合，卷积把局部性与位置间复用直接写进运算；它们既可以构成完整网络，也可以成为同一个网络中的不同模块。

例如，要检测图像一行中相邻像素的亮度变化，可以对数值 $(1, 2, 4, 3)$ 依次计算相邻两项之差，得到 $(-1, -2, 1)$ 。三个位置都使用“左值减右值”这一组局部权重，而不是各学一套权重，这展示了卷积的局部共享方式。全连接层则可以让每个输出同时读取四项亮度，并各自学习四个输入权重。两种计算都能从输入向输出执行，因而“前馈”并不能决定采用哪一种交互。

在不规则关系图上，**消息传递**（message passing）让节点接收并聚合相邻节点的信息，再更新自己的表示。沿用路口例子，可以先对相邻路口的车流表示取平均，再与本路口的表示共同计算新值。与规则网格上的卷积相比，它由输入图决定邻域，节点的邻居数量可以不同。若用注意力根据当前车流表示计算不同邻居的贡献，就把固定的等权平均改为内容相关的加权组合。此时消息传递与注意力同时出现：前者规定参与交互的关系范围，后者规定当前输入下各关系的相对影响。

注意力还可以让一组位置在指定的可见范围内直接相互读取。卷积核的共享参数在推理时通常保持固定，注意力的聚合权重则根据当前表示计算。这里比较的是聚合方式；一个卷积网络也可以加入注意力模块，一个 Transformer 也包含注意力之外的前馈变换。因此，“以注意力为主”不表示全部计算都是注意力。

状态空间更新通过内部状态累积历史影响。一个离散、线性、时不变的

基础形式是

$$\begin{aligned}\mathbf{s}^{(t)} &= \mathbf{A}\mathbf{s}^{(t-1)} + \mathbf{B}\mathbf{x}_t, \\ \mathbf{o}_t &= \mathbf{C}\mathbf{s}^{(t)} + \mathbf{D}\mathbf{x}_t,\end{aligned}\tag{7.9}$$

其中 $\mathbf{x}_t \in \mathbb{R}^d$ 是第 t 步输入, $\mathbf{s}^{(t)} \in \mathbb{R}^m$ 是状态, $\mathbf{o}_t \in \mathbb{R}^r$ 是输出, 递推从给定的 $\mathbf{s}^{(0)}$ 开始。矩阵 $\mathbf{A} \in \mathbb{R}^{m \times m}$ 、 $\mathbf{B} \in \mathbb{R}^{m \times d}$ 、 $\mathbf{C} \in \mathbb{R}^{r \times m}$ 和 $\mathbf{D} \in \mathbb{R}^{r \times d}$ 在这组公式中不随 t 改变。该线性模块可以与非线性变换组合成神经网络, 输入相关更新则改变了这里的时不变假设。并行计算与递归计算能否互换, 需要检查具体更新形式, 不能从“状态空间”这一名称直接推出。

这些交互方式分别决定读取范围、参数如何复用、权重是否由当前内容产生, 以及历史如何保留。它们与上一小节的连接分类并不是同一维度: 卷积常用于前馈结构, 消息传递可以按固定轮数前馈, 也可以反复更新状态; 状态空间模块则可以在多个层之间堆叠。判断计算代价和表达限制时, 需要同时说明具体机制与组织方式。

7.4.3 按信息编码方式划分

前面的式子大多用实数向量记录单元活动。**连续值激活**(continuous-valued activation) 用数值的大小表达当前响应, 信息通过这些数值之间的运算传递。这里的“连续值”描述数学表示; 计算机中的浮点数和量化数仍是有限精度编码, 不能把数学上的实数模型与实际数值存储混为一谈。

脉冲编码则用离散事件及其发生时刻表达信息。例如, 在固定观察窗口内, 脉冲数量可以反映响应强弱; 也可以用首次发放时间或多个脉冲的相对时刻表达差异。后一种读法把时间本身纳入表示, 不能只用窗口内的计数代替。具体如何编码输入、维护内部状态与读取输出, 需要同神经元动态一起设计。

同一个图像分类任务可以采用不同编码。假设某像素的归一化强度为 0.6, 连续值输入直接传递这个数; 一种教学用计数编码把观察窗口分成 10 个时隙, 其中 6 个时隙各发放一次脉冲, 读取端再用计数除以 10 还原 0.6。这个例子只约定数量, 不约定哪六个时隙发放; 若模型还利用事件时刻, 就必须进一步指定时间安排。无论采用哪种编码, 都仍可以让单元读取局部像素并共享参数, 所以编码方式与卷积交互不是二选一。

两种编码可以对应相近的任务, 却改变了计算和学习所需处理的对象。连续值网络可以直接对数组数值做矩阵运算; 事件驱动实现可以在事件到来时处理相应更新, 但也可能需要维护没有发放脉冲的单元状态。发放事件的离散性还使普通导数的使用遇到困难, 需要专门的学习方法。是否节省运行代价, 取决于事件密度、实现方式和硬件, 不能仅由编码名称判断。

表 7.1 用三个已经解释的维度比较代表形式。表中的描述限定了相应结构, 而不是给所有同名变体统一贴标签。一个采用脉冲编码的卷积网络同

时具有局部共享运算和事件信号；一个带注意力的循环网络则同时具有状态递推和内容相关聚合。这些组合保留了各维度的意义。

代表形式	连接组织	主要交互	信号编码
层状全连接网络	层间前馈	稠密加权组合	连续值激活
前馈卷积网络	层间前馈	局部连接与参数共享	连续值激活
带注意力的循环网络	状态递推	状态更新与动态聚合	连续值激活
固定轮数的图消息传递网络	按轮次展开	按输入图聚合邻居	连续值激活
前馈脉冲卷积网络	层间前馈，单元保留状态	局部连接与参数共享	脉冲事件

表 7.1 同一个网络可以同时按三个维度描述。连接组织回答计算怎样依赖，交互方式回答信息怎样组合，编码方式回答单元传递什么信号。列出的形式用于展示分类交叉，不穷尽各类网络的变体。

7.5 本章小结

神经网络把特征构造纳入可学习的计算路径。异或例子说明，原始坐标中的线性限制可以通过非线性中间表示改变，输出端仍可使用简单规则。多个单元共同编码信息、多个层继续组合表示，为这种变换提供了两种互补的组织方式。表示是否适合任务，则由输入信息、结构假设、学习目标与算法共同决定。

生物启发提供了单元、连接和可塑性的出发点；视觉感受野与层次组合进一步解释了局部连接的设计动机。腹侧与背侧通路还提示，物体身份与空间动作需要的表示并不相同。生物比较还揭示了预测反馈、复用经验与多感官交互的作用；少样本表现、鲁棒性和能效的差异，则必须连同已有知识、任务条件与实现范围一起判断。人工预测模型与生物解释有不同的证据要求。网络发展始终受表示、学习和计算条件的共同约束：隐藏层扩展候选函数，反向传播提供梯度，结构组织交互，数据与实现支持训练。这些条件共同把计算关系变成可训练、可使用的模型。

后续各章将展开结构假设：前馈网络解释逐层计算与梯度，卷积网络利用局部性和参数共享，循环网络研究状态递推，图神经网络利用实体关系，Transformer 展开内容相关交互，脉冲网络研究事件编码与时间动态。理解这些结构，还应分别检验表达能力、训练可行性与泛化表现。

前馈神经网络

第7章用异或说明了隐藏表示的作用：两个非线性单元就能把原始坐标中无法线性分开的样本变成可分的表示。但那组权重是手工给出的。面对真实数据，网络应当怎样组织这些单元，训练目标怎样决定各层参数的变化，又凭什么相信训练结果可以用于未见样本？这三个问题分别关系到计算结构、参数学习和预测能力，不能仅凭网络层数或训练误差回答。

本章以层状、全连接的前馈网络为主要对象，把前章的函数复合落实为可计算、可求导的模型。网络结构规定候选函数及其输出含义，参数学习把最终损失对各层参数的影响算出来，理论分析则区分表达一个函数与从有限数据学得低风险预测规则。常见应用把这些要素接回完整的输入、训练和预测过程。读者可以沿用前文的向量、矩阵、损失和梯度知识；复杂度与稳定性的结论主要承接第二卷“基础、理论和可信性”的“深度学习的可学习性”章，不在这里重复一般证明。

8.1 网络结构

前馈性质规定的是计算依赖的方向：同一次前向计算中，后续结果不会沿有向环返回上游。它并没有要求每个单元必须连接所有输入，也没有要求所有层宽相同。本节采用最直接的全连接结构，说明一次预测究竟计算什么，再考察激活函数和输出目标怎样改变这种计算。

8.1.1 神经元

要把一组输入变成新的特征，可以让一个人工神经元读取若干数值，计算加权求和，再通过激活函数得到输出。设单元的输入为 $\mathbf{u} \in \mathbb{R}^m$ ，权重为 $\mathbf{w} \in \mathbb{R}^m$ ，偏置为 $b \in \mathbb{R}$ ，则

$$z = \mathbf{w}^\top \mathbf{u} + b, \quad h = \sigma(z). \quad (8.1)$$

权重决定各个输入怎样共同影响单元，偏置改变单元响应的位置。这里的 z 称为**预激活值**（pre-activation），即非线性变换之前的加权结果； h 是单

元输出。没有偏置时，ReLU 单元的分界 $\mathbf{w}^\top \mathbf{u} = 0$ 必须经过原点，加入偏置后便能移动这条分界。

同一层的多个单元可以各自读取整组输入，用不同权重计算不同坐标。这种**全连接层**（fully connected layer）让下一层每个单元与上一层每个单元相连。把一个单元的权重按行放入矩阵，就能用一次矩阵运算计算整层。沿用前章的列向量约定，设网络有 L 个隐藏层，输入为 $\mathbf{x} \in \mathbb{R}^d$ ，令 $d_0 = d$ 、 $\mathbf{h}^{(0)} = \mathbf{x}$ ，各隐藏层依次计算

$$\begin{aligned} \mathbf{z}^{(\ell)} &= \mathbf{W}_\ell \mathbf{h}^{(\ell-1)} + \mathbf{b}_\ell, \\ \mathbf{h}^{(\ell)} &= \sigma_\ell(\mathbf{z}^{(\ell)}), \quad \ell = 1, \dots, L. \end{aligned} \quad (8.2)$$

其中 $\mathbf{W}_\ell \in \mathbb{R}^{d_\ell \times d_{\ell-1}}$ 、 $\mathbf{b}_\ell \in \mathbb{R}^{d_\ell}$ ， $\mathbf{z}^{(\ell)}$ 和 $\mathbf{h}^{(\ell)}$ 都属于 $\mathbb{R}^{d_\ell}$ ， σ_ℓ 逐坐标作用。上标 ℓ 表示层的位置，不是幂，也不是参数更新的迭代步。

隐藏层之后还需一个与任务相配的输出层。记原始输出为 $\mathbf{a} \in \mathbb{R}^q$ 、 $d_{L+1} = q$ ，完整模型写为

$$\begin{aligned} \mathbf{a} &= \mathbf{W}_{L+1} \mathbf{h}^{(L)} + \mathbf{b}_{L+1}, \\ \hat{\mathbf{y}} &= g(\mathbf{a}). \end{aligned} \quad (8.3)$$

矩阵 $\mathbf{W}_{L+1} \in \mathbb{R}^{q \times d_L}$ 和向量 $\mathbf{b}_{L+1} \in \mathbb{R}^q$ 参与学习，输出变换 g 由任务决定。 g 可以是恒等映射，也可以把得分转换为概率。用 $\boldsymbol{\theta} \in \mathbb{R}^p$ 收集全部权重与偏置，模型记为 $\mathbf{f}_\theta(\mathbf{x}) = \hat{\mathbf{y}}$ ；标量输出时写 f_θ 。

图 8.1 展示了这种分层依赖。输入层只提供数据，不计算一组新的可学习参数；隐藏层的每个坐标都是一次式(8.1)的计算。这就是前章引入的多层感知机：具有一个或多个全连接隐藏层、用非线性变换构造表示的前馈网络。这个名称不意味着现代 MLP 必须使用早期感知机的硬阈值激活。

对没有参数共享的上述网络，参数总数为

$$p = \sum_{\ell=1}^{L+1} d_\ell (d_{\ell-1} + 1). \quad (8.4)$$

括号内的两项分别来自每个单元的输入权重和偏置。若输入维度为 100，两个隐藏层宽度均为 64，输出维度为 1，参数数量为 $64 \times 101 + 64 \times 65 + 65 = 10689$ 。这说明输入编码和层宽会直接改变模型规模。忽略激活和偏置的较小开销，一次单样本前向计算的乘加量与 $\sum_\ell d_\ell d_{\ell-1}$ 同阶；参数数量并不能单独说明表达是否高效或预测是否可靠。

本文把 L 称为隐藏层数，把 d_ℓ 称为第 ℓ 层宽度。文献中的**深度**（depth）有时包含输出层，有时只计隐藏层，比较结果时应核对口径。跨层连接只要不构成有向环，也可以保持前馈性质；本章的逐层推导采用普通串联结构。




图 8.1 两个隐藏层的全连接前馈神经网络。蓝色圆点提供输入 $\mathbf{x}$ ，红色圆点计算隐藏表示，黄色圆点产生原始得分 $\mathbf{a}$ ，之后再使用任务规定的输出变换 g 。细线表示可学习的连接，层间箭头标明前向计算方向；每个目标单元还具有一个未画出的偏置。图中层宽依次为 3, 4, 3, 2，只是结构示例。

8.1.2 激活函数

前章已经证明，连续叠加仿射层仍然只是一次仿射变换。隐藏层需要非线性激活，使不同输入范围可以有不同响应。但非线性也会改变导数：有些函数把大幅输入变化压成很小的输出变化，有些函数把一部分输入直接置零，还有些函数让响应形状参与学习。选择激活函数时，需要同时考察表示、梯度、输出约束和计算成本。

本节按响应方式介绍常见函数：恒等与阶跃作为基准，双侧饱和函数限制输出范围，整流与指数型函数保留较大的正响应，自门控函数平滑地调节输入，Maxout 与 Softmax 则联合处理多个预激活值。带参数函数的图像必须固定参数才能比较；随机函数还需区分训练与预测阶段。除特别说明外，输入记为标量 z ，输出记为 $\sigma(z)$ 。

8.1.2.1 恒等与阶跃

若需要保留任意实数输出，可以使用**恒等函数**（identity function）；若只需要一个硬的二值判定，可以使用**阶跃函数**（step function）。两者分别为

$$\text{Identity}(z) = z, \quad H(z) = \begin{cases} 0, & z < 0, \\ 1, & z \geq 0. \end{cases} \quad (8.5)$$

恒等函数的导数为 1，常用于回归输出或无需额外激活的投影；全部隐藏层都用恒等函数时，多层串联仍是仿射映射。阶跃函数适合表达阈值决策，但除阈值处不可微之外，在其余位置导数都为 0，普通反向传播无法据此学习阈值单元的输入参数。预测时作硬判定与训练时使用连续可导替代，是两种不同用途。




图 8.2 恒等函数与阶跃函数的比较。左图保留输入，斜率恒为 1；右图按零阈值输出 0 或 1，空心点和实心点区分 $z = 0$ 两侧的端点约定。横轴为预激活值 z ，纵轴为输出；阶跃图中的跳跃不能通过普通局部导数传递学习信号。

8.1.2.2 双侧饱和函数

当一个单元需要产生概率、控制系数或有界状态时，把任意实数压到有限区间是直接的选择。**Logistic 函数**产生 $(0, 1)$ 内的响应，实践中常直接称为 Sigmoid；**双曲正切函数** (hyperbolic tangent, Tanh) 产生 $(-1, 1)$ 内的响应。Sigmoid 也可泛指具有 S 形曲线的一类函数，这里用 s 专门表示 Logistic 函数：

$$\begin{aligned} s(z) &= \frac{1}{1 + \exp(-z)}, & s'(z) &= s(z)(1 - s(z)), \\ \tanh(z) &= \frac{\exp(z) - \exp(-z)}{\exp(z) + \exp(-z)}, & \tanh'(z) &= 1 - \tanh^2(z). \end{aligned} \quad (8.6)$$

当 $|z|$ 很大时，输出接近两端的极限，导数趋近于零。这种**饱和** (saturation) 意味着输入继续变化，输出却几乎不变。Sigmoid 导数至多为 $1/4$ ；Tanh 在原点的导数为 1，并满足 $\tanh(z) = 2s(2z) - 1$ 。Tanh 关于原点对称，可以产生正负响应，但只有对称输入分布等条件才能进一步推出输出均值为零。

Sigmoid 适合二分类概率、多标签概率和取值在 $(0, 1)$ 的控制门；它不会自动赋予任意隐藏坐标概率意义。Tanh 适合需要正负有界状态的模块，例如后续循环网络中的候选状态。两者用于许多层连续串联时，饱和区的小导数可能参与梯度衰减；传播中还包含权重矩阵，不能只凭激活导数判断整个梯度必然变小。

若希望避免指数运算，可以用分段线性函数近似上述有界响应。**硬 Sig-**

moid (hard sigmoid, 也称 Hard-Logistic) 和**硬 Tanh** (hard tanh) 将线性段之外的值截到边界:

$$\begin{aligned}\text{HardSigmoid}(z) &= \min\{1, \max\{0, \frac{1}{4}z + \frac{1}{2}\}\}, \\ \text{HardTanh}(z) &= \min\{1, \max\{-1, z\}\}.\end{aligned}\quad (8.7)$$

本节的 **HardSigmoid** 在 $(-2, 2)$ 内斜率为 $1/4$, 区间外为 0; **HardTanh** 在 $(-1, 1)$ 内斜率为 1, 区间外为 0, 其负端输出是 -1 。分段边界处的导数需要约定。**HardSigmoid** 的线性段并没有唯一标准, 一些实现采用 $z/6 + 1/2$ 并在 ± 3 处截断; 移植模型时必须核对具体定义¹。

两种硬近似可用于受计算资源限制的门控或范围约束, 代价是拐点不可微, 截断区内还会出现严格为零的梯度。**Softsign 函数** 提供另一种有界响应, 用绝对值而非指数控制幅度:

$$\text{Softsign}(z) = \frac{z}{1 + |z|}, \quad \text{Softsign}'(z) = \frac{1}{(1 + |z|)^2}. \quad (8.8)$$

它的值域也是 $(-1, 1)$, 一阶导数连续, 尾部导数以多项式速度趋零。它可用于需要有界正负响应的隐藏层或状态映射; 与 **Tanh** 相比, 尾部衰减方式不同, 并不意味着在所有输入尺度下梯度都更大。

¹ PyTorch Contributors, *Hard-sigmoid*, URL: <https://docs.pytorch.org/docs/2.14/generated/torch.nn.Hardsigmoid.html> (visited on 10/02/2026)




图 8.3 双侧饱和激活函数。左图比较 Logistic / Sigmoid、Tanh 与 Softsign; Softsign 采用长虚线, 以便在黑白打印中仍能与 Sigmoid 区分, 图例同时指出前者按代数速度、后者按指数速度趋近渐近值。右图将 **HardSigmoid** 和 **HardTanh** 与对应平滑函数比较。**HardSigmoid** 采用式(8.7)中的斜率 $1/4$ 及截断点 ± 2 。

8.1.2.3 整流函数及其变体

ReLU 采用前章的 $\rho(z) = \max\{0, z\}$, 正半轴斜率为 1, 负半轴输出和导数都为 0。它只需比较与取值, 能够产生严格为零的激活, 可作为全连接或卷积隐藏层的基础选择。如果某单元对所有训练样本都长期落在负半轴, 其输入权重可能难以得到数据梯度。这种失活要结合参数、数据和更新方式判断; 在较深层, 上游表示本身仍可能改变。

让负半轴保留非零斜率, 可以避免该区域完全阻断局部梯度。**带泄漏的**

ReLU (leaky ReLU) 使用固定 $0 < \alpha < 1$, **参数化 ReLU** (parametric ReLU, PReLU) 则把负半轴斜率作为待学习参数:

$$\begin{aligned}\text{LeakyReLU}(z) &= \max\{0, z\} + \alpha \min\{0, z\}, \\ \text{PReLU}_j(z) &= \max\{0, z\} + \alpha_j \min\{0, z\}.\end{aligned}\quad (8.9)$$

PReLU 的 α_j 可以按单元、通道设置, 也可以在一层内共享; 若不另加约束, 它并不天然位于 $(0, 1)$ 。给定上游梯度, 斜率参数的局部求导规则是 $\partial \text{PReLU}_j(z)/\partial \alpha_j = \min\{0, z\}$, 共享斜率时要累加各使用位置的贡献。PReLU 增加的参数量取决于共享方式, 通常每个单元、通道或层只增加一个斜率参数²。

Leaky ReLU 适合希望保留负响应且不增加待学习参数的隐藏层, PReLU 适合允许数据调整负响应强度的模块。**随机化带泄漏 ReLU** (randomized leaky ReLU, RReLU) 沿用同一段形式, 但训练时从预先规定的区间 $[l, u]$ 均匀采样负斜率 α , 其中 $0 < l < u < 1$, 预测时通常采用 $(l + u)/2$ 。这种训练扰动可作为正则化设计的一部分, 不能把训练阶段画成唯一固定曲线; 它是否改善预测表现仍需评价³。

如果部署还要求限制正响应, 可以使用**ReLU6 函数**, 即

$$\text{ReLU6}(z) = \min\{6, \max\{0, z\}\}.\quad (8.10)$$

它在 $(0, 6)$ 内保留斜率 1, 在两侧导数为 0, 常与移动端模型及有限数值范围的设计联系在一起。MobileNetV2 使用了这类有界整流响应, 但其线性瓶颈层还刻意省略非线性, 说明激活要按层的职责选择⁴。ReLU6 不是处处保持正半轴梯度的 ReLU; 超过上界的输入也会进入饱和区。

² K. He, X. Zhang, S. Ren, J. Sun, *Delving Deep into Rectifiers: Surpassing Human-Level Performance on ImageNet Classification* In Proceedings of the IEEE International Conference on Computer Vision, 2015, pp. 1026–1034

³ B. Xu, N. Wang, T. Chen, M. Li, *Empirical Evaluation of Rectified Activations in Convolutional Network* In arXiv preprint arXiv:1505.00853, 2015

⁴ M. Sandler, A. Howard, M. Zhu, A. Zhmoginov, L.-C. Chen, *MobileNetV2: Inverted Residuals and Linear Bottlenecks* In arXiv preprint arXiv:1801.04381, 2018




图 8.4 整流函数与负斜率变体。左图固定 Leaky ReLU 的 $\alpha = 0.1$ 、PReLU 的 $\alpha_j = 0.25$, 并以 $\alpha = 0.2$ 画出 RReLU 训练阶段的一种可能曲线; 三者的形状差异来自斜率选择, PReLU 与 RReLU 的区别主要在参数取得方式。右图比较 ReLU 与 ReLU6, 展示 $z > 6$ 时的截断。两图横轴范围不同。

有界函数与整流函数的差异集中在表 8.1 中。Sigmoid、Tanh 和 Softsign 限制两端幅度, ReLU 只截断负半轴, ReLU6 还限制正端; 这种范围差异

会直接改变哪些输入能够传递梯度。

函数	输出范围	导数与参数特点	适用场景及主要边界
Identity	$\mathbb{R}$	导数为 1	回归输出、线性投影；不增加非线性
阶跃	$\{0, 1\}$	非阈值处导数为 0	硬判定；不能直接靠普通反向传播训练
Sigmoid	$(0, 1)$	两端导数趋零	二分类、多标签、控制门
Tanh	$(-1, 1)$	两端导数趋零	有界正负状态；深层饱和需关注
HardSigmoid	$[0, 1]$	截断区导数为 0	简单门控；需核对斜率与截断点
HardTanh	$[-1, 1]$	截断区导数为 0	有界状态；拐点与严格零梯度
Softsign	$(-1, 1)$	一阶连续，尾部导数趋零	有界正负表示；尾部衰减方式不同
ReLU	$[0, +\infty)$	负半轴为 0，正半轴为 1	全连接、卷积隐藏层；可能失活
Leaky ReLU	$\mathbb{R}$	固定正负斜率	保留负梯度；斜率需设定
PReLU	依赖 α_j	负斜率参与学习	学习响应形状；需说明参数共享方式
RReLU	$\mathbb{R}$	训练时随机负斜率	隐藏层训练扰动；预测规则不同
ReLU6	$[0, 6]$	两侧截断，中间斜率为 1	有限范围、移动端；正端也会饱和

表 8.1 有界响应与整流激活的比较。Leaky ReLU 和 RReLU 的范围按正负斜率均为正且非零书写；PReLU 若不限斜率，其输出范围随参数改变。所有分段函数都需在不可微边界约定求导规则。

即使都用于限制输出幅度，求导行为也可能不同。Tanh 和 HardTanh 都提供有界正负响应；按解析定义，前者在有限输入下保留非零导数，后者在截断区的导数严格为零。选择范围约束时，还需判断训练中的预激活值是否经常落到这些区域。

8.1.2.4 指数型与平滑整流函数

固定负斜率让负输出无限下降，另一种做法是使负响应逐渐接近一个有限下界。**指数线性单元**（exponential linear unit, ELU）在正半轴保留输入，在负半轴使用指数曲线：

$$\text{ELU}_{\alpha}(z) = \begin{cases} z, & z > 0, \\ \alpha(\exp(z) - 1), & z \leq 0, \end{cases} \quad \alpha > 0. \quad (8.11)$$

负半轴导数为 $\alpha \exp(z)$ ，对有限负输入非零，但在 $z \rightarrow -\infty$ 时趋零；输出趋近 $-\alpha$ 。ELU 连续，只有 $\alpha = 1$ 时左右一阶导数才在原点一致，而且此时也不具有所有阶的连续导数。ELU 可用于希望保留负值并控制负端幅度的隐藏层；输出存在负值并不保证任意数据下的均值恰好为零⁵。

缩放指数线性单元（scaled exponential linear unit, SELU）进一步把 ELU 整体乘以固定系数：

$$\text{SELU}(z) = \kappa \begin{cases} z, & z > 0, \\ \alpha(\exp(z) - 1), & z \leq 0, \end{cases} \quad (8.12)$$

其中常用常数为 $\alpha \approx 1.6733$ 、 $\kappa \approx 1.0507$ 。它用于**自归一化网络**（self-normalizing neural network），即在规定假设下让层间激活的均值与方差

⁵ D.-A. Clevert, T. Unterthiner, S. Hochreiter, *Fast and Accurate Deep Network Learning by Exponential Linear Units (ELUs)* In arXiv preprint arXiv:1511.07289, 2016

趋向受控范围的前馈网络。相应分析依赖输入与权重的统计条件；常配合输入标准化、权重方差为 $1/\text{fan-in}$ 的初始化，以及为保持统计量设计的 AlphaDropout。这里 fan-in 是一个单元的输入连接数，初始化的具体说明见第 8.2.1 节。自归一化不是把 ReLU 换成 SELU 后就无条件得到的保证，也不能随意混用初始化和丢弃规则⁶。

如果目标是输出严格正值而又保持平滑，可以使用 **Softplus 函数**：

$$\text{Softplus}(z) = \log(1 + \exp(z)), \quad \text{Softplus}'(z) = s(z). \quad (8.13)$$

它在正端接近 z ，在负端趋近 0，但有限输入下输出严格大于 0，不会产生 ReLU 式的精确零激活。Softplus 可作为平滑隐藏激活，也适合将任意得分映射为正尺度、强度或方差参数；需要严格正下界时还可加上一个固定小常数。计算时使用 $\max\{z, 0\} + \log(1 + \exp(-|z|))$ 可避免指数溢出。因此是否使用 Softplus 应按平滑性和正值约束判断，不能仅凭某个分类实验就认定它在所有场景中都不合适。




图 8.5 ELU、SELU 与 Softplus 的响应。ELU 使用 $\alpha = 1$ ，SELU 使用式(8.12)中的常数，ReLU 作为共同参照。ELU 与 SELU 允许负输出并在负端趋向有限下界；Softplus 始终为正，且平滑地趋近正半轴上的线性响应。

8.1.2.5 自门控函数

ReLU 根据输入的正负作硬切换，也可以让输入乘一个连续变化的系数。**Swish 函数**使用输入自身计算保留系数：

$$\text{Swish}_{\beta}(z) = zs(\beta z), \quad \beta \geq 0. \quad (8.14)$$

β 可以固定，也可以参与学习。 $\beta = 0$ 时函数为 $z/2$ ； $\beta = 1$ 时得到 **Sigmoid 加权线性单元** (sigmoid-weighted linear unit, SiLU)；当 $\beta \rightarrow +\infty$ 时，对每个固定输入趋向 ReLU。这里的变化描述响应曲线的极限，不能据此推出不同 β 的训练效果也连续地在两种模型之间变化⁷。

⁶ G. Klambauer, T. Unterthiner, A. Mayr, S. Hochreiter, *Self-Normalizing Neural Networks In Advances in Neural Information Processing Systems*, 2017

⁷ P. Ramachandran, B. Zoph, Q. V. Le, *Searching for Activation Functions In arXiv preprint arXiv:1710.05941*, 2017

Swish 的局部导数为

$$\begin{aligned} \text{Swish}'_{\beta}(z) &= s(\beta z) + \beta z s(\beta z)(1 - s(\beta z)), \\ \frac{\partial \text{Swish}_{\beta}(z)}{\partial \beta} &= z^2 s(\beta z)(1 - s(\beta z)). \end{aligned} \quad (8.15)$$

SiLU 因而不是与 Swish 完全不同的函数，而是其固定参数实例。SiLU 在强化学习函数逼近等场景中也有使用⁸。SiLU 可作为全连接、卷积或门控前馈模块中的平滑激活；在有限负区间内导数可能为负，负尾部导数又趋零。若学习 β 并要求保持非负，还需明确约束方式。

⁸ S. Elfwing, E. Uchibe, K. Doya, *Sigmoid-Weighted Linear Units for Neural Network Function Approximation in Reinforcement Learning* In *Neural Networks*, 2018, vol. 107, pp. 3–11




图 8.6 Swish 在不同 β 下的函数图像。 $\beta = 0$ 给出线性函数 $z/2$ ， $\beta = 1$ 就是 SiLU，较大的 β 逐渐形成接近 ReLU 的响应。图中参数固定为 0, 0.5, 1, 5，ReLU 用作极限参照；它不展示可学习 β 在某次训练中的实际轨迹。

高斯误差线性单元 (Gaussian error linear unit, GELU) 采用标准正态累积分布函数 Φ 作为保留系数：

$$\text{GELU}(z) = z\Phi(z), \quad \text{GELU}'(z) = \Phi(z) + z\varphi(z). \quad (8.16)$$

其中 $\varphi(z) = \exp(-z^2/2)/\sqrt{2\pi}$ 是标准正态密度。GELU 在全实数上平滑，但公式中的分布函数只定义一个确定变换，并不表示执行时随机丢弃输入。它常作为 Transformer 前馈模块的激活选择，平滑性本身不能保证找到更好的最优解。常见近似为 $zs(1.702z)$ ，或者

$$\text{GELU}(z) \approx \frac{z}{2} \left(1 + \tanh \left[\sqrt{\frac{2}{\pi}} (z + 0.044715z^3) \right] \right). \quad (8.17)$$

使用哪种近似会改变实际数值与导数，复现模型时应记录具体形式。上述近似与精确定义的关系是数值近似，不是把 GELU 与 SiLU 视为同一个函数⁹。

Mish 函数进一步用 Softplus 和 Tanh 形成平滑的保留系数¹⁰。其定义为

$$\text{Mish}(z) = z \tanh(\text{Softplus}(z)). \quad (8.18)$$

⁹ D. Hendrycks, K. Gimpel, *Gaussian Error Linear Units (GELUs)* In arXiv preprint arXiv:1606.08415, 2016

¹⁰ D. Misra, *Mish: A Self Regularized Non-Monotonic Activation Function* In arXiv preprint arXiv:1908.08681, 2019

令 $t = \tanh(\text{Softplus}(z))$ ，乘积与链式法则给出导数 $t + zs(z)(1 - t^2)$ 。Mish 在负半轴保留一段负响应，负尾部趋近零，正端接近线性，可作为视觉网络或普通隐藏层的另一种平滑选择；原论文的比较依赖具体模型与数据，不能概括为普遍优于其他激活。

这些平滑函数需要指数、Tanh 或正态分布函数计算。若希望用简单分段运算近似 SiLU，可使用**硬 Swish** (hard swish, Hardswish)。MobileNetV3 在面向移动端的结构中使用这种响应¹¹。其定义为

$$\text{Hardswish}(z) = z \frac{\text{ReLU6}(z + 3)}{6} = \begin{cases} 0, & z \leq -3, \\ z(z + 3)/6, & -3 < z < 3, \\ z, & z \geq 3. \end{cases} \quad (8.19)$$

¹¹ A. Howard, M. Sandler, G. Chu, L.-C. Chen, B. Chen, M. Tan, W. Wang, Y. Zhu, R. Pang, V. Vasudevan, Q. V. Le, H. Adam, *Searching for MobileNetV3* In arXiv preprint arXiv:1905.02244, 2019

它在中间区间的导数为 $(2z + 3)/6$ ，在两端分别为 0 和 1，在 ± 3 处不具有唯一导数。这里的门采用斜率 1/6 的硬 Sigmoid 形式，不能直接替换成本节前面斜率 1/4 的版本。实际速度取决于算子与硬件实现，而不只取决于公式中出现几个基本运算。




图 8.7 SiLU、GELU、Mish 与 Hardswish。左图展示整体响应，右图放大原点附近的负值和过渡区域；GELU 按标准正态累积分布函数采样。它们在正端接近线性，但负区间的形状和拐点不同。SiLU、GELU 与 Mish 平滑，Hardswish 含有分段边界；两图使用不同坐标标范围以显示细节。

8.1.2.6 Maxout 与 Softmax

以上函数分别作用于一个标量。若希望一个单元从若干候选响应中选择最大者，可以使用**Maxout 单元** (maxout unit)：它先计算 K 个仿射响应，再取最大值，响应的分段形状由权重学习得到。对于输入 $\mathbf{u} \in \mathbb{R}^m$ ，其定义为

$$z_k = \mathbf{w}_k^\top \mathbf{u} + b_k, \quad h = \max_{1 \leq k \leq K} z_k, \quad (8.20)$$

其中每个 $\mathbf{w}_k \in \mathbb{R}^m$ 、 $b_k \in \mathbb{R}$ 都参与学习。只有一个严格最大响应时，梯度传给这一响应；多个响应并列最大时需约定分配方式。固定一个响应为零、另一个为 $\mathbf{w}^\top \mathbf{u} + b$ ，就得到 ReLU 这一特殊形式。一个 Maxout 单元

对输入表示为凸分段仿射函数，不意味着包含多个 Maxout 层的完整网络只能表示凸函数¹²。

Maxout 适合希望学习分段响应形状的隐藏单元，也曾与 Dropout 联合研究。相对于一个普通仿射响应，它有 K 套权重与偏置，参数和响应计算量通常约增至 K 倍，而不是无论 K 多大都只增加一倍。它不包含固定的负半轴零梯度区域，但某些分支仍可能长期不是最大者而收不到梯度。它不再是式(8.2)中逐坐标作用于一个仿射响应的激活，反向计算需使用最大值选择对应的规则。

若目的不是选择一个最大数值，而是把 K 个得分转换为互斥事件的概率，可以使用**Softmax 变换**。对 $\mathbf{z} \in \mathbb{R}^K$ ，其第 k 个输出为

$$p_k = \text{softmax}(\mathbf{z})_k = \frac{\exp(z_k)}{\sum_{j=1}^K \exp(z_j)}, \quad \sum_{k=1}^K p_k = 1. \quad (8.21)$$

每个概率依赖全部输入坐标，所以不存在脱离其他得分的唯一一元 Softmax 曲线。其雅可比为 $\partial p_k / \partial z_j = p_k(\mathbb{I}\{k=j\} - p_j)$ 。Softmax 适合互斥多分类输出和需要归一化权重的模块；多标签输出则通常分别使用 Sigmoid。训练时把 Softmax 与交叉熵合并，可以得到更直接且数值稳定的梯度，下一小节将展开。




图 8.8 Maxout 和 Softmax 的一维观察方式。左图取三个仿射候选 $-z-1$ 、 $0.5z$ 和 $2z-1$ ，粗实线是它们的最大值包络；它展示固定参数后沿一维输入的 Maxout 响应。右图固定三类得分为 $(z, 0, 0)$ ，绘出三项 Softmax 概率，其中 $p_2 = p_3$ ，用同一条曲线标注。这些切片不能代表所有输入与参数下的唯一函数图像。

8.1.2.7 激活函数的比较与选择

表 8.1 归纳了前面的有界响应与整流函数，表 8.2 补充指数型、自门控与向量变换。比较时，先确定该层需要输出什么，再检查梯度和计算代价。表中的使用场景说明功能匹配；可学习参数和随机机制也需要与固定曲线区分。

若该层预测概率或正尺度，输出约束通常决定选择：互斥类别用 Softmax，

¹² I. Goodfellow, D. Warde-Farley, M. Mirza, A. Courville, Y. Bengio, *Maxout Networks* In Proceedings of the 30th International Conference on Machine Learning, 2013, pp. 1319–1327

函数	输出范围	导数与参数特点	适用场景及主要边界
ELU	$(-\alpha, +\infty)$	负端导数趋零, α 固定	允许负响应; 零均值没有无条件保证
SELU	$(-\kappa\alpha, +\infty)$	固定缩放与负指数响应	自归一化 MLP; 需配套统计条件
Softplus	$(0, +\infty)$	平滑, 导数为 Sigmoid	正尺度输出、平滑隐藏层; 无精确零
Swish / SiLU	依赖 β	β 固定或学习, SiLU 取 1	平滑隐藏层、前馈模块; 局部可非单调
GELU	有负下界, 正端无界	平滑, 精确式或近似式	Transformer 前馈模块; 非随机采样
Mish	有负下界, 正端无界	平滑, 复合运算	视觉或其他隐藏层; 收益需验证
Hardswish	$[-3/8, +\infty)$	两个分段边界	移动端响应; 速度取决于实现
Maxout	依赖候选仿射响应	选中分支获梯度, K 套参数	学习分段函数; 分支可能少获梯度
Softmax	概率单纯形内部	联合依赖全部得分	互斥类别、归一化权重; 非逐坐标激活

表 8.2 指数型、自门控与向量变换的比较。Swish 在 $\beta = 0$ 时是线性函数; 其余正 β 情形具有有限负下界。Softmax 按 $K \geq 2$ 书写, 输出各项严格为正且总和为 1。表中的平滑性描述固定参数的标量函数, 不能替代整条计算路径的可微性检查。

多个可共存标签分别用 Sigmoid, 正尺度可以用 Softplus。若该层构造隐藏表示, 则需要比较非线性、活动范围与梯度。ReLU 提供简单的分段响应, Leaky ReLU 与 PReLU 保留负梯度, GELU 与 SiLU 提供平滑过渡; SELU 则是与特定初始化和统计条件配套的设计, 不能只当作另一条任意替换的曲线。

计算成本也必须放回实现环境。分段线性函数少用指数等运算, 但向量化、融合算子和内存访问可能改变实际耗时。平滑函数可能便于需要连续导数的模型, 但不会自动避免小梯度或改善泛化; 增加可学习斜率也可能改变初始化时的合适尺度。比较预测性能时, 应固定数据划分、结构和评价口径, 并说明是否重新调节学习率与初始化, 才能区分激活变化和配套设置变化的影响。

8.1.2.8 从阈值单元到平滑门控：发展脉络

McCulloch 与 Pitts 在 1943 年把神经活动的“全或无”性质写成阈值单元; Rosenblatt 在 1958 年的感知机工作中进一步讨论了连接如何从样本中调整¹³。这些早期模型用单元的开关组合表达判定。硬阈值便于表达逻辑关系, 但其普通导数几乎处处为零, 无法直接承担本章所用的多层梯度学习。

当隐藏层需要通过损失学习表示时, 连续响应提供了可用的局部导数。Rumelhart、Hinton 与 Williams 在 1986 年的反向传播论文中使用 Logistic 响应, 展示了隐藏单元怎样随训练形成特征。这一工作将可微的连续响应与隐藏表示的学习结合起来, 使激活函数的选择与训练机制紧密相连¹⁴。

Sigmoid 与 Tanh 随后也暴露出深层训练的尺度问题: 两端饱和时, 导数会变小, Sigmoid 在原点附近又有非零的输出基线。2010 年 Glorot 与 Bengio 的工作把激活响应与初始化放在一起分析, 说明不能只要求单个函数可导, 还要检查数值和梯度经过多层之后是否仍有合适尺度。Tanh 把输出中心移到零附近, 但仍保留两端饱和的边界¹⁵。

这项工作的对照还表明, 即使保留同一种激活, 改变权重初始化方式

¹³ W. S. McCulloch, W. Pitts, *A Logical Calculus of the Ideas Immanent in Nervous Activity* In *The Bulletin of Mathematical Biophysics*, 1943, vol. 5, pp. 115–133; F. Rosenblatt, *The Perceptron: A Probabilistic Model for Information Storage and Organization in the Brain* In *Psychological Review*, 1958, vol. 65, no. 6, pp. 386–408

¹⁴ D. E. Rumelhart, G. E. Hinton, R. J. Williams, *Learning representations by back-propagating errors* In *Nature*, 1986, vol. 323, no. 6088, pp. 533–536

¹⁵ X. Glorot, Y. Bengio, *Understanding the Difficulty of Training Deep Feedforward Neural Networks* In *Proceedings of the Thirteenth International Conference on Artificial Intelligence and Statistics*, 2010, pp. 249–256

也会改变各层活动值与梯度的尺度。选择激活函数时，因而还要把初始化和层深放在一起考察：一条曲线的局部斜率不足以描述整条网络的训练状态。第8.2.1节将从信号的二阶矩出发解释这种配合，区分 Tanh 的中心响应与 ReLU 的半轴截断。

整流函数让设计重点转向稀疏响应和正半轴上的线性传播。Nair 与 Hinton 在 2010 年研究了受限玻尔兹曼机中的整流单元；Glorot、Bordes 与 Bengio 在 2011 年进一步比较深层前馈网络的整流与 Tanh 响应。这两项工作分别在生成模型与深层判别网络中展示了整流响应的作用。正半轴不饱和缓解了一类梯度衰减，负半轴的零导数又促使后续方法保留泄漏斜率或允许负响应¹⁶。

较新的分支把注意力转向平滑过渡与输入相关的门控。2016 年的 GELU 按输入幅度平滑加权；2017 年的 Swish 工作通过函数搜索研究自门控响应，并与 ReLU 比较。两者都保留较大的正响应，同时用平滑过渡替代正负区域之间的硬切换¹⁷。

本节介绍的带斜率变体、指数响应和硬近似，分别延伸了可学习形状、信号尺度与计算成本这些方向。历史上的改进解决的是特定结构和训练设置中的问题；今天选择隐藏激活时仍需核对这些条件。Sigmoid 和 Softmax 在概率输出中的用途，则由预测对象决定，并不因隐藏层采用 ReLU 或平滑门控而消失。

8.1.3 输出和学习目标

隐藏层得到的是一组可供后续使用的数值，输出层则要回答任务中的具体问题：预测一个连续数值、判断一个事件是否成立、从多个类别中选一个，还是生成供其他模块使用的表示？这些问题对应不同的输出空间。选定输出变换 g 之后，还需用损失函数说明什么预测算好、错误怎样计分。下面始终把最后一层的原始得分记为 $\mathbf{a}$ ，区分原始得分、预测结果与训练损失。

图 8.9 把五种任务放在同一个前馈结构之后比较：左侧逐层形成隐藏表示，右侧按任务选择一个输出头，即把隐藏表示转换成所需预测的最后一组计算。各头有各自的权重、偏置和训练目标；图中的分支表示可替换的方案，并不表示必须同时训练五个任务。

8.1.3.1 回归：预测连续数值

回归的目标是连续数值，例如经过单位缩放的房价。对标量目标 $y \in \mathbb{R}$ ，令 $q = 1$ ，输出层只产生一个得分 $\mathbf{a}$ ；采用恒等变换 $g(\mathbf{a}) = \mathbf{a}$ 时，预测值就是 $\hat{y} = \mathbf{a}$ 。平方损失衡量预测值与目标的距离：

$$\ell(\mathbf{a}, y) = \frac{1}{2}(\mathbf{a} - y)^2, \quad \frac{\partial \ell}{\partial \mathbf{a}} = \mathbf{a} - y. \quad (8.22)$$

¹⁶ V. Nair, G. E. Hinton, *Rectified Linear Units Improve Restricted Boltzmann Machines* In Proceedings of the 27th International Conference on Machine Learning, 2010, pp. 807–814; X. Glorot, A. Bordes, Y. Bengio, *Deep Sparse Rectifier Neural Networks* In Proceedings of the Fourteenth International Conference on Artificial Intelligence and Statistics, 2011, pp. 315–323

¹⁷ D. Hendrycks, K. Gimpel, *Gaussian Error Linear Units (GELUs)* In arXiv preprint arXiv:1606.08415, 2016; P. Ramachandran, B. Zoph, Q. V. Le, *Searching for Activation Functions* In arXiv preprint arXiv:1710.05941, 2017

共同的前馈网络

按任务选择一个输出头




图 8.9 共同的前馈结构与五种可替换的输出头。左侧蓝色输入单元经红色隐藏单元形成 $\mathbf{h}^{(L)}$ ；汇合线传递整组隐藏坐标，不执行求和。右侧黄色单元产生各任务自己的原始得分，每个单元都读取全部隐藏坐标，并具有独立的输出权重与偏置。(a)、(b) 只需一个得分；(c) 联合归一化，(d) 逐坐标变换；(e) 产生由下游任务约束的表示。向量头仅画三个坐标示意，实际维度由任务决定。右侧文字区分预测量与训练目标，隐藏激活无需与输出变换相同。

系数 $1/2$ 用于简化导数，不改变仅有这一损失时的最优预测。若教学样本的目标为 2.5、当前预测为 2，损失为 0.125，对输出的导数为 -0.5 ；沿负梯度方向调整输出，会让它增大并接近目标。多个连续目标可以使用向量输出，以及 $\frac{1}{2}\|\mathbf{a} - \mathbf{y}\|_2^2$ ；不同坐标的单位与尺度需要在数据处理或损失权重中考虑。

平方损失还规定了预测的统计含义。在二阶矩有限、可选函数足够自由

时, 使条件期望损失最小的预测是 $E[y | \mathbf{x}]$, 即给定输入后的条件均值。因而同一个输入对应多种可能结果时, 平方损失倾向于预测它们的均值, 并不直接输出所有可能结果。

输出范围应与目标配合。若预测正尺度, 可以令 $\hat{y} = \text{Softplus}(a)$, 再对 $\hat{y}$ 计算损失; 此时对 a 求导还需乘输出变换的导数。若同时预测不确定性, 可以让网络输出均值和正方差, 再用所选概率分布的负对数似然训练。约束预测值的范围与建立一个完整的条件分布, 是两个不同的设计决定。

8.1.3.2 二分类: 预测一个正类概率

二分类判断一个事件是否成立, 例如一封邮件是否属于垃圾邮件。令 $y \in \{0, 1\}$, 其中 1 表示正类。输出层仍只需要一个实数 a , 经过 Sigmoid 得到

$$p = s(a), \quad P_{\theta}(y = 1 | \mathbf{x}) = p, \quad P_{\theta}(y = 0 | \mathbf{x}) = 1 - p.$$

这里 p 是模型给出的正类概率, a 称为 **logit**, 即对数几率 $\log(p/(1-p))$ 。两个类别的概率已经由 p 和 $1-p$ 共同确定, 无须再设置两个彼此独立的概率输出。

在这个伯努利模型下, 正确标签的概率为 $p^y(1-p)^{1-y}$ 。对它取负对数, 就得到二元交叉熵:

$$\begin{aligned} \ell(a, y) &= -y \log p - (1-y) \log(1-p) \\ &= \log(1 + \exp(a)) - ya. \end{aligned} \tag{8.23}$$

若 $y = 1$ 而 $p = 0.8$, 损失约为 0.2231; 若把这个正例的概率降到 0.2, 损失会增至约 1.6094。交叉熵不仅考察最后选对哪一类, 还区分模型给正确标签分配了多少概率。

式(8.23)以原始得分 a 为输入, 把 Sigmoid 和损失合在一起计算。其稳定形式为 $\max\{a, 0\} - ya + \log(1 + \exp(-|a|))$, 导数为 $\partial \ell / \partial a = p - y$ 。这避免了先得到极接近 0 或 1 的概率再取对数。预测类别时还需选定阈值 τ , 例如按 $p \geq \tau$ 判为正类; 误判代价或业务约束不同, 所需阈值也可能不同。硬判定用于决策, 连续概率与损失用于学习。

图 8.9(a)、(b) 把回归与二分类放在同一隐藏结构上比较。两者都可以只产生一个原始得分, 差别发生在输出解释和学习目标; 二分类的概率变换不会要求隐藏层也使用 Sigmoid。

8.1.3.3 互斥多分类: 预测一个类别

若一个样本恰好属于 K 个类别中的一个, 例如一张数字图像对应一个数字类别, 需要输出一组相互竞争的概率。设 $y \in \{1, \dots, K\}$ 、 $q = K$, 输出层

的每个坐标 a_k 是对应类别的原始得分。Softmax 将整组得分转换为概率：

$$p_k = \frac{\exp(a_k)}{\sum_{j=1}^K \exp(a_j)}, \quad \sum_{k=1}^K p_k = 1, \quad \hat{y} = \arg \max_k p_k. \quad (8.24)$$

最大概率并列时还需约定决策规则。与逐坐标使用 Sigmoid 相比, Softmax 的分母让所有类别共同参与归一化: 提高一个类别的概率, 必然改变至少一个其他类别的概率。

正确标签的概率为 p_y 。多类交叉熵就是这个概率的负对数, 把 Softmax 代入后可写成

$$\ell(\mathbf{a}, \mathbf{y}) = -\log p_y = -a_y + \log \sum_{j=1}^K \exp(a_j). \quad (8.25)$$

对 a_k 求导得到 $p_k - \mathbb{I}\{y = k\}$ 。例如教学样本有三类, $y = 2$ 、 $\mathbf{p} = (0.1, 0.7, 0.2)^\top$, 则损失约为 0.3567, 得分梯度为 $(0.1, -0.3, 0.2)^\top$ 。负梯度方向倾向于提高正确类别得分、降低其他类别得分; 是否以及怎样改变这些得分, 还取决于网络参数和输入。

向全部得分加同一个常数, 不会改变概率。因此计算时可减去 $c = \max_j a_j$, 使指数不超过 1; 对数求和项计算为 $c + \log \sum_j \exp(a_j - c)$ 。分类由相对得分决定, 原始得分本身既不要求为正, 也不要求加起来等于 1。

8.1.3.4 多标签分类: 预测多个二值结果

一个对象也可能同时具有多个标签。例如同文档可以同时属于“技术”和“教育”, 而不属于“体育”。这时要分别判断每个标签是否成立, 而不能强迫模型只选择一个类别。**多标签分类** (multi-label classification) 的目标为 $\mathbf{y} \in \{0, 1\}^K$, 输出层产生 K 个得分, 对每个坐标分别使用 Sigmoid:

$$\begin{aligned} p_k &= s(a_k), \\ \ell(\mathbf{a}, \mathbf{y}) &= \sum_{k=1}^K [-y_k \log p_k - (1 - y_k) \log(1 - p_k)] \\ &= \sum_{k=1}^K [\log(1 + \exp(a_k)) - y_k a_k]. \end{aligned} \quad (8.26)$$

每个坐标都对应一次二分类, 概率总和不必须为 1。例如目标为 $(1, 1, 0)^\top$, 预测为 $(0.8, 0.7, 0.1)^\top$, 概率总和为 1.6, 按阈值 0.5 会选出前两个标签。损失中前两项奖励相应概率增大, 第三项则奖励该标签的概率减小。

式(8.26)采用标签损失求和; 也可以按标签数取平均, 但会相应改变梯度尺度。每个得分的导数仍为 $p_k - y_k$, 不同标签可以设置各自的决策阈值。这里“分别使用”描述输出变换和损失的组织方式; 若把各标签的伯

努利概率乘起来解释为联合分布，就采用了给定输入后的标签条件独立模型。共享隐藏层能利用共同特征，但这种输出头本身没有显式建立标签之间的联合依赖。

图 8.9(c)、(d) 对比了同样输出三个得分的两种任务。Softmax 把三个类别放进一次竞争，逐坐标 Sigmoid 则允许多个标签同时成立。输出维度相同，不能据此选择相同的概率变换和决策规则。

8.1.3.5 表示输出：由下游目标提供约束

有时网络的输出不会立即解释成类别或数值，而是交给另一个模块做比较、分类或重建。例如，编码器输出一组坐标，后续分类头再根据这些坐标预测标签。此时可以直接使用 $\mathbf{r} = \mathbf{a} \in \mathbb{R}^q$ ，也可以根据下游任务约束表示的长度；当 $\mathbf{a} \neq \mathbf{0}$ 时，单位长度表示为

$$\mathbf{r} = \frac{\mathbf{a}}{\|\mathbf{a}\|_2}。 \quad (8.27)$$

例如 $(3, 4)^\top$ 会变成 $(0.6, 0.8)^\top$ 。这一变换保留方向，去掉整体长度差异；它改变了输出的几何约束，却没有指定哪些对象应当相近、哪些坐标应当携带什么信息。

表示的学习信号必须来自目标。接上分类头时，分类损失的梯度经过这个头传回表示网络；做重建时，由重建误差规定需要保留的信息；按样本关系学习时，则需说明怎样奖励相近样本、区分不同样本。只要求相近样本的表示相同，可能让全部输入得到同一个表示；单位长度约束也不能排除这种情况。因而“输出一个向量”与“学到有用表示”之间，还缺少与使用目的相配的训练约束。

图 8.9(e) 把表示输出与下游目标相连。前馈网络产生表示，下游模块把表示用于具体任务，损失的梯度再沿这条计算路径传回。若去掉下游目标，就只剩一次向量变换，还没有规定应学到什么。

8.1.3.6 从单样本损失到训练目标

上面的输出头规定了一条预测怎样计分。训练时，所有样本共享同一组参数，目标还需汇总各样本损失。设训练集为 $S = ((\mathbf{x}_i, \mathbf{y}_i))_{i=1}^n$ ，标量标签按对应任务书写，记网络对第 i 个输入产生的原始输出为 $\mathbf{a}_i(\theta)$ ，则

$$J_S(\theta) = \frac{1}{n} \sum_{i=1}^n \ell(\mathbf{a}_i(\theta), \mathbf{y}_i) + \lambda \Omega(\theta)。 \quad (8.28)$$

这里把输出变换并入损失，回归中的恒等变换、二分类的 Sigmoid 和多分类的 Softmax 分别按上面的公式处理。表示输出则把下游目标与表示网络连成同一计算路径。 Ω 是可选的参数惩罚， $\lambda \geq 0$ 控制惩罚强度。

输出维度、隐藏层数和层宽是设计时确定或用验证集选择的超参数，权重与偏置则从训练数据学习。概率输出满足取值范围，只说明模型形式正确；预测概率是否与实际发生频率一致，还需用数据评价。由此，输出头回答“网络预测什么”，损失回答“训练奖励什么”，决策规则回答“预测怎样用于行动”。这三者应当在同一任务设定下配合。

8.2 参数学习

确定结构和目标之后，学习过程需要一个起点，也需要知道每个参数应沿哪个方向调整。初始化影响初始表示及梯度的尺度，反向传播计算各参数对损失的局部影响，自动微分把这些计算规则应用到程序上。优化方法使用所得梯度更新参数；反向传播本身并不负责选择学习率或保证找到全局最优解。

8.2.1 参数初始化

初始化要解决两个问题：让同层单元从不同起点学习，并让数值与梯度在层间传播时保持合适尺度。Sigmoid、Tanh 和 ReLU 都提供非线性，但对输入的压缩方式不同，因此随机权重不能只按层宽设置，还需与隐藏激活配合。下面先给出共同的尺度估计，再按饱和响应、整流响应和其他用途分别讨论。

8.2.1.1 共同要求：打破对称并控制尺度

若同一隐藏层单元的输入权重、偏置以及相应的输出连接完全相同，在相同数据和对称更新规则下，它们的输出与梯度也会保持相同。全零初始化就是典型的对称起点：增加了单元数，却没有让它们承担不同的计算。随机初始化权重可以打破这种对称性；偏置通常可初始化为零，因为不同权重已经让单元响应有所区别。

随机性的作用不等于尺度控制。设某层输入坐标的二阶矩为 $q_{\text{in}} = \mathbb{E}[u_k^2]$ ，初始权重独立、均值为零、方差为 v ，权重与输入独立，偏置为零。对有 m 个输入的单元， $z = \sum_{k=1}^m w_k u_k$ 满足

$$\mathbb{E}[z^2] = mvq_{\text{in}}. \quad (8.29)$$

交叉项因不同权重独立且均值为零而消失。若激活保持输入尺度，则 v 应随 m 缩小，避免连接数增加时预激活幅度持续增大；若激活会压缩或截断输入，还需补上相应影响。

输入连接数 $m = d_{\ell-1}$ 称为**fan-in**；同一输入坐标通向的输出连接数 d_ℓ 称为**fan-out**。前向计算关心每个输出汇总了多少输入，后向计算关心每个

输入汇总了多少输出的影响。两种连接数不同，就可能需要在保持前向尺度与保持后向尺度之间作折中。

8.2.1.2 Sigmoid 与 Tanh：同一饱和族，中心尺度不同

本章的 Sigmoid 特指 Logistic 函数 $s(z)$ 。它与 Tanh 有精确关系：

$$\tanh(z) = 2s(2z) - 1, \quad s(z) = \frac{1 + \tanh(z/2)}{2}. \quad (8.30)$$

因此两者属于相近的 S 形饱和响应：足够大的正负输入都会进入变化缓慢的尾部。它们的区别在于坐标缩放与输出中心。Sigmoid 的输出位于 $(0, 1)$, $s(0) = 1/2$ ；Tanh 的输出位于 $(-1, 1)$, $\tanh(0) = 0$ 。在关于零对称的输入分布下，Tanh 因奇对称性具有零均值，而 Sigmoid 的均值为 $1/2$ ；非对称输入下则不能保证 Tanh 输出零均值。

两者在中心附近的斜率也不同： $s'(0) = 1/4$, $\tanh'(0) = 1$ 。如果许多隐藏层在中心附近使用 Sigmoid，激活导数本身就会反复缩小反向信号；若预激活幅度过大，Sigmoid 和 Tanh 又都会饱和。增大权重虽然能放大仿射变换，却可能把更多单元推入小导数区域，不能靠无限放大权重补偿衰减。

对中心附近近似单位斜率的激活，把式(8.29)用于前向传播，得到 $v \approx 1/\text{fan-in}$ ；对后向传播作类似独立性近似，得到 $v \approx 1/\text{fan-out}$ 。**Glorot 初始化** (Glorot initialization, 也称 Xavier 初始化) 采用折中方差

$$v = \frac{2}{d_{\ell-1} + d_{\ell}}, \quad (\mathbf{w}_{\ell})_{j,k} \sim \mathcal{U}\left[-\sqrt{\frac{6}{d_{\ell-1} + d_{\ell}}}, \sqrt{\frac{6}{d_{\ell-1} + d_{\ell}}}\right]. \quad (8.31)$$

$\mathcal{U}$ 表示均匀分布，也可以使用同方差的零均值正态分布。Tanh 在原点附近符合上述单位斜率近似，因而常与这一尺度配合；实际设置可再按所选激活的增益调整。Glorot 与 Bengio 的原文同时分析了 Sigmoid 的非零输出中心和饱和问题，这些因素会使近似线性传播的条件更难成立¹⁸。

8.2.1.3 ReLU 及其变体：补偿被截断的响应

ReLU 采用不同的响应机制：它在正半轴保留输入、导数为 1，在负半轴输出和导数都为 0。因此它没有正端饱和，但会截断一部分信号；若单元对全部训练样本都处于负区间，又可能长期没有输入参数的学习信号。前述饱和函数两端导数趋零，与这里负区间导数严格为零，是不同的机制。

若预激活 z 的分布关于零对称，ReLU 满足

$$\mathbb{E}[\rho(z)^2] = \frac{1}{2}\mathbb{E}[z^2].$$

¹⁸ X. Glorot, Y. Bengio, *Understanding the Difficulty of Training Deep Feedforward Neural Networks* In Proceedings of the Thirteenth International Conference on Artificial Intelligence and Statistics, 2010, pp. 249–256

这条关系控制的是二阶矩；ReLU 输出通常具有正均值，不能直接称为方差保持。把截断因子 $1/2$ 代入式(8.29)，为近似保持前向激活的二阶矩，**He 初始化**（He initialization，也称 Kaiming 初始化）采用

$$(\mathbf{w}_\ell)_{j,k} \sim \mathcal{N}\left(0, \frac{2}{d_{\ell-1}}\right). \quad (8.32)$$

相对于单位增益响应的 $1/\text{fan-in}$ ，系数 2 补偿了对称分布下负半轴被截断的二阶矩。

若负半轴保留斜率 α ，则 $\mathbb{E}[\sigma(z)^2] = (1 + \alpha^2)\mathbb{E}[z^2]/2$ ，对应前向权重方差为 $2/((1 + \alpha^2)d_{\ell-1})$ 。这适用于初始化时固定斜率的 Leaky ReLU，也可用于 PReLU 的初始斜率；斜率开始学习后，初始尺度不再是全过程保证。若主要保持后向梯度的二阶矩，可将分母中的 fan-in 换成 fan-out，所控制的传播方向应明确¹⁹。

8.2.1.4 其他隐藏激活与任务输出：分别设置

GELU、SiLU 和 ELU 的负区间响应不同，不具有 ReLU 完全相同的截断关系，因此不能仅凭正端近似线性就原样套用系数 2。SELU 又是把激活常数与特定统计条件配套考虑的设计，应沿用其对应的初始化和结构条件。选择其他激活时，需要检查所用实现的增益约定、输入尺度和层宽，并观察初始活动值与梯度；这些检查没有给出统一的训练全过程保证。

隐藏激活与输出变换也应分开判断。二分类网络可以在隐藏层用 ReLU、在输出处用 Sigmoid：前者构造表示，后者把一个得分解释成概率，它们承担不同职责。ReLU 隐藏层可采用式(8.32)，但线性得分层没有负半轴截断，无须自动继承同一系数。二分类输出还需关注初始 logit 是否过大，而不能把“最后使用 Sigmoid”理解为所有隐藏层都要按饱和函数初始化。

以上尺度推导利用的是初始化时的分布与独立性假设。训练后，权重、表示与上游梯度可能相关，因而保持初始二阶矩不等于一直保持梯度，也不等于保证优化成功。初始化、输入标准化、激活函数与更新方式需要共同配合；后面的反向传播将说明梯度具体如何穿过这些计算。

8.2.2 反向传播

隐藏层没有直接给定的目标值，怎样判断某个隐藏权重应当增大还是减小？一个权重改变了本层输出，本层输出改变了后续表示，后续表示又改变最终损失。链式法则把这些局部影响相乘并汇总。**反向传播**（backpropagation）按照与前向依赖相反的顺序组织这项计算，让不同参数重复利用已经算出的中间导数。

先固定一个样本，把输出变换与损失合为标量函数 $\ell(\mathbf{a}, \mathbf{y})$ 。用列向量

¹⁹ K. He, X. Zhang, S. Ren, J. Sun, *Delving Deep into Rectifiers: Surpassing Human-Level Performance on ImageNet Classification* In Proceedings of the IEEE International Conference on Computer Vision, 2015, pp. 1026–1034

表示梯度，定义

$$\delta^{(L+1)} = \nabla_a \ell, \quad \delta^{(\ell)} = \nabla_{\mathbf{z}^{(\ell)}} \ell \quad (\ell = 1, \dots, L). \quad (8.33)$$

向量 $\delta^{(\ell)} \in \mathbb{R}^{d_\ell}$ 记录损失对本层各预激活坐标的敏感程度。它常被称为反向传播的“误差”，但一般并不是本层输出减去某个隐藏标签；隐藏层并没有这样的标签。

由式(8.3)，输出得分对 $\mathbf{h}^{(L)}$ 的雅可比为 $\mathbf{W}_{L+1}$ ，所以损失对最后一个隐藏表示的梯度为 $\mathbf{W}_{L+1}^\top \delta^{(L+1)}$ 。隐藏激活逐坐标作用，其雅可比是以各坐标导数为对角元素的矩阵。把两步链式法则合起来，便得到逐层递推：

$$\delta^{(\ell)} = \left(\mathbf{W}_{\ell+1}^\top \delta^{(\ell+1)} \right) \odot \sigma'_\ell(\mathbf{z}^{(\ell)}), \quad \ell = L, \dots, 1. \quad (8.34)$$

其中 $\odot$ 表示逐坐标乘法。矩阵转置把后层各单元的影响汇总到当前坐标，激活导数再调整这些影响能有多少通过本层。递推中的每个向量维度都是 d_ℓ ，因此可逐层核对计算是否匹配。

参数的导数来自本层仿射运算。对任一层 $\ell = 1, \dots, L+1$ ，第 j 个预激活值对权重 $(\mathbf{W}_\ell)_{j,k}$ 的导数是 $h_k^{(\ell-1)}$ ，对偏置 $(\mathbf{b}_\ell)_j$ 的导数是 1。由此得到

$$\nabla_{\mathbf{W}_\ell} \ell = \delta^{(\ell)} (\mathbf{h}^{(\ell-1)})^\top, \quad \nabla_{\mathbf{b}_\ell} \ell = \delta^{(\ell)}. \quad (8.35)$$

第一式是一个外积：每条连接的梯度等于目标单元的损失敏感度乘以来源单元的活动值。矩阵形状为 $d_\ell \times d_{\ell-1}$ ，恰好与权重相同。对输入的梯度则为 $\nabla_{\mathbf{x}} \ell = \mathbf{W}_1^\top \delta^{(1)}$ ；即使输入不参与参数更新，这个量也能用于分析预测对输入变化的敏感程度。

输出层的起点由任务决定。采用式(8.22)时， $\delta^{(L+1)} = a - y$ ；采用二元交叉熵时， $\delta^{(L+1)} = p - y$ ；采用多类交叉熵时，第 k 个坐标为 $p_k - \mathbb{I}\{y = k\}$ ，其中 $\mathbb{I}$ 是事件成立时为 1 的指示函数。概率输出与交叉熵合并后得到的简洁导数，是两者配合的结果。若 Sigmoid 输出后使用平方损失，导数还包含 $s'(a)$ ，不能沿用 $p - y$ 。

图 8.10 把下面算例的 2-3-1 网络展开，说明前向值与反向梯度的区别。前向计算提供各层的预激活和表示；反向计算从损失开始，重复利用这些值与局部导数。梯度向上游传播不会改变本次前向预测已经使用的输入，也不会给预测网络增加有向环。

示例 8.1 一次前向与反向计算 沿用异或的二值输入，使用图 7.1 中的 2-3-1 结构：一个隐藏层含三个 ReLU 单元，输出得分经 Sigmoid 变成二分类概率。下面的参数是教学构造，不是已训练好的异或分




图 8.10 示例 8.1 中 2-3-1 网络的计算图。上方连线的黑色数字给出前向传递值，红色数字给出相应的反向量；预激活与隐藏表示是同一隐藏层的两种数值，不是两个隐藏层。下方红色虚线按向量形式汇总梯度，坐标顺序与上方节点从上到下一致。第三个单元通过输出权重 0.5 收到梯度，第二个单元的梯度被负半轴上的 ReLU 截断。数值按更新前参数计算，梯度和概率保留四位小数。

类器：

$$\mathbf{W}_1 = \begin{pmatrix} 1 & -1 \\ -1 & 1 \\ 1 & 1 \end{pmatrix}, \quad \mathbf{b}_1 = \begin{pmatrix} 0.2 \\ 0.2 \\ -0.2 \end{pmatrix},$$

$$\mathbf{W}_2 = \begin{pmatrix} 1 & 1 & 0.5 \end{pmatrix}, \quad b_2 = -0.5.$$

对样本 $\mathbf{x} = (1, 0)^\top$ 、 $y = 1$ ，前向结果为

$$\mathbf{z}^{(1)} = (1.2, -0.8, 0.8)^\top,$$

$$\mathbf{h}^{(1)} = (1.2, 0, 0.8)^\top,$$

$$a = 1 \times 1.2 + 1 \times 0 + 0.5 \times 0.8 - 0.5 = 1.1.$$

因而 $p = s(1.1) \approx 0.7503$ ，二元交叉熵 $\ell = -\log p \approx 0.2873$ 。本例三个预激活值都远离 ReLU 的不可微点，局部导数依次为 1, 0, 1。

输出敏感度为 $\delta^{(2)} = p - 1 \approx -0.2497$ 。先乘输出权重的转置，再逐坐标乘激活导数，得到

$$\begin{aligned}\nabla_{\mathbf{h}^{(1)}} \ell &\approx (-0.2497, -0.2497, -0.1249)^\top, \\ \delta^{(1)} &\approx (-0.2497, 0, -0.1249)^\top, \\ \nabla_{\mathbf{w}_1} \ell &\approx \begin{pmatrix} -0.2497 & 0 \\ 0 & 0 \\ -0.1249 & 0 \end{pmatrix}, \quad \nabla_{\mathbf{b}_1} \ell \approx \begin{pmatrix} -0.2497 \\ 0 \\ -0.1249 \end{pmatrix}.\end{aligned}$$

例如第三个隐藏单元的第一条输入权重，其梯度是

$$\frac{\partial \ell}{\partial (\mathbf{w}_1)_{3,1}} = (p - 1) \times 0.5 \times 1 \times x_1 \approx -0.1249.$$

这四个因子依次来自输出损失、输出连接、ReLU 局部导数和输入值。输出参数的梯度为 $\nabla_{\mathbf{w}_2} \ell \approx (-0.2997, 0, -0.1998)$ 、 $\partial \ell / \partial b_2 \approx -0.2497$ ；继续回传到输入则有 $\nabla_{\mathbf{x}} \ell \approx (-0.3746, 0.1249)^\top$ 。第一层第一、第三个单元对 x_2 的权重梯度为零，是因为这个样本的 $x_2 = 0$ ；第二个单元的输入权重梯度为零，则来自负半轴上的激活导数。两种零梯度有不同原因。

若仅用该样本、不加正则项，并以学习率 0.1 同时更新所有参数，即每项参数减去 0.1 倍的对应梯度，则更新后的参数为

$$\begin{aligned}\mathbf{w}_1^{(1)} &\approx \begin{pmatrix} 1.0250 & -1 \\ -1 & 1 \\ 1.0125 & 1 \end{pmatrix}, \quad \mathbf{b}_1^{(1)} \approx \begin{pmatrix} 0.2250 \\ 0.2 \\ -0.1875 \end{pmatrix}, \\ \mathbf{w}_2^{(1)} &\approx \begin{pmatrix} 1.0300 & 1 & 0.5200 \end{pmatrix}, \quad b_2^{(1)} \approx -0.4750.\end{aligned}$$

参数上标 (1) 表示一次更新。用未舍入的梯度重算该输入，隐藏表示约为 $(1.2499, 0, 0.8250)^\top$ ，得分约为 1.2414，正类概率约为 0.7758，损失约为 0.2539。该正例的损失下降，不代表全部异或样本的总损失或新样本风险也降低。

训练目标通常包含多个样本，它们共享同一组参数，因此梯度需要相加。若本次更新读取一个索引集合 $B \subseteq \{1, \dots, n\}$ ，称为**小批量** (mini-batch)，其平均数据梯度为

$$\mathbf{G}_\ell = \frac{1}{|B|} \sum_{i \in B} \delta_i^{(\ell)} (\mathbf{h}_i^{(\ell-1)})^\top, \quad \mathbf{r}_\ell = \frac{1}{|B|} \sum_{i \in B} \delta_i^{(\ell)}. \quad (8.36)$$

这里 $\mathbf{G}_\ell \in \mathbb{R}^{d_\ell \times d_{\ell-1}}$ 是权重梯度矩阵， $\mathbf{r}_\ell \in \mathbb{R}^{d_\ell}$ 是偏置梯度向量。每个样本的 $\delta_i^{(\ell)}$ 按未除以批量大小的单样本损失计算。若反向起点已经使用批平

均损失，便不应在这里再次除以 $|B|$ 。矩阵实现可将样本按列排列，用同样的矩阵乘法一次计算这些外积之和；样本按行排列的实现会相应改变转置位置。

若 $\Omega = \frac{1}{2} \sum_{\ell} \|\mathbf{W}_{\ell}\|_F^2$ ，其中 $\|\cdot\|_F$ 是矩阵各元素平方和开方得到的 Frobenius 范数，则权重总梯度为 $\mathbf{G}_{\ell} + \lambda \mathbf{W}_{\ell}$ ，未被惩罚的偏置不加这一项。给定学习率 $\eta_t > 0$ ，普通梯度更新为

$$\begin{aligned}\mathbf{W}_{\ell}^{(t+1)} &= \mathbf{W}_{\ell}^{(t)} - \eta_t (\mathbf{G}_{\ell} + \lambda \mathbf{W}_{\ell}^{(t)}), \\ \mathbf{b}_{\ell}^{(t+1)} &= \mathbf{b}_{\ell}^{(t)} - \eta_t \mathbf{r}_{\ell}.\end{aligned}\quad (8.37)$$

这里迭代上标 t 与层下标 ℓ 分别记录训练时刻和结构位置。

算法 8.1 前馈网络的小批量梯度学习

输入： 训练集 S 、验证集、网络结构、损失、学习率序列与停止规则

输出： 经验证集选择的参数 θ

- 1: 按激活与层宽初始化权重，初始化偏置
- 2: **while** 尚未达到停止规则 **do**
- 3: 读取小批量 B ，保存各样本的预激活、隐藏表示与输出
- 4: 计算输出敏感度 $\delta_i^{(L+1)}$
- 5: **for** $\ell = L, L-1, \dots, 1$ **do**
- 6: 按式(8.34)计算 $\delta_i^{(\ell)}$
- 7: **end for**
- 8: 汇总所有层的数据梯度，并加入所选惩罚项的梯度
- 9: 使用同一更新前参数计算的梯度，同时更新各层参数
- 10: 按既定间隔评估验证集，记录待选择的参数
- 11: **end while**
- 12: 返回按预先规定验证指标选择的参数

算法 8.1 把求导和更新分成两步。如果在尚未完成反向计算时就改写某层权重，前后各层的梯度可能对应不同的参数，便不再是同一个目标在同一点的梯度。停止规则可以包含最大更新次数和验证指标的停止条件；优化器、学习率安排及更广泛的训练问题将在训练章比较。

反向传播的计算量与前向矩阵运算同阶，因为每层主要计算转置矩阵乘法和外积，而不是为每个参数重新运行网络。它通常还要保存各层的活动值，单样本隐藏激活的存储量与 $\sum_{\ell} d_{\ell}$ 同阶，小批量时随批量大小增长。逐层导数相乘也解释了小梯度和大梯度如何累积：能够正确求出梯度，并不保证这个梯度具有适合更新的尺度。

用十次连乘就能看清这种累积。只考虑一条经过 10 个 Sigmoid 单元的标量路径，并假设路径上各权重的绝对值不超过 1。由于每个激活导数至多为 0.25，沿这条路径回传的敏感度，其绝对值至多乘上

$$0.25^{10} = \frac{1}{1048576} \approx 9.54 \times 10^{-7}。$$

这只是该路径的上界，不是任意网络完整梯度的值：多个路径的贡献需要相加，较大的权重也可能放大信号。对串联的 10 个 Sigmoid 向量层，若各层权重矩阵的谱范数均不超过 1，回传向量穿过这 10 层后，其范数也至多乘上这个因子。谱范数衡量一次线性变换对向量长度的最大放大倍数，这个条件不能仅由每项权重不超过 1 替代。梯度经过多层后变得很小、使上游参数难以获得有效更新，称为**梯度消失**（vanishing gradients）。

反过来，若一条标量路径经过 10 个处于正半轴的 ReLU 单元，每条权重均为 2，则这些单元的激活导数为 1，路径上的回传倍数为 $2^{10} = 1024$ 。这是权重与激活状态持续配合造成的放大，展示了**梯度爆炸**（exploding gradients）的机制；一个权重较大，并不保证完整梯度必然爆炸。两种算术都说明，判断梯度尺度必须检查整条路径上的乘积，而不能只看单个激活是否可导。

8.2.3 自动梯度计算

普通串联网络的梯度可以手工推导，但模型加入多个分支、共享参数或额外损失以后，逐项维护公式很容易遗漏一条影响路径。要把求导交给程序，需要说明程序到底在算什么。数值微分、符号微分和自动微分都能提供导数信息，采用的原理却不同。

数值微分（numerical differentiation）通过改变输入后观察函数值之差来近似导数。例如，用第 j 个标准基向量 $\mathbf{e}_j$ 和步长 $\varepsilon > 0$ ，中心差分为

$$\frac{\partial J}{\partial \theta_j} \approx \frac{J(\theta + \varepsilon \mathbf{e}_j) - J(\theta - \varepsilon \mathbf{e}_j)}{2\varepsilon} \quad (8.38)$$

在足够光滑且附近高阶导数受控时，其截断误差随 ε^2 缩小；步长过小时，两次接近的函数值相减又会放大浮点误差。得到 p 个参数的完整梯度通常需要约 $2p$ 次目标计算，所以它适合检查少量梯度或方向导数，不适合直接承担大网络的每次更新。检查 ReLU 网络时应避开激活切换点，否则差分可能跨越两个不同的线性区域。

符号微分（symbolic differentiation）按照求导规则变换表达式，例如把 $\frac{1}{2}(uv + u)^2$ 变成关于 u, v 的导数公式，再在某一点求值。它能给出可以继续分析的表达式，但未经简化和公共子表达式复用，复杂复合函数的导数表达式可能迅速膨胀。符号方法也可以利用共享结构；因此不能把表达式膨胀说成所有符号求导实现都无法避免的性质。

自动微分（automatic differentiation, AD）把程序实际执行的计算拆成具有已知局部导数的基本运算，在计算数值的同时或之后应用链式法则。它不通过有限扰动估计导数，也不必先展开整个导数表达式。若所执行运算可微且局部求导规则正确，所得结果是这条计算路径的导数在当前点的数值，仍受浮点舍入影响；自动微分并不意味着无限精度，也不意味着不

可微的程序自动变得可微。

8.2.3.1 算子图与前向模式

为了区分两种传播方向，考虑数学函数 $J(u, v) = \frac{1}{2}(uv + u)^2$ 。把计算拆成 $r = uv$ 、 $s = r + u$ 、 $t = s^2$ 和 $J = t/2$ ，就得到乘法、加法、平方与缩放四个算子。每个算子只读取前面已经得到的值，输入 u 则分别进入乘法和加法，形成两条影响输出的路径。

前向模式 (forward mode) 随前向值一起传播某个输入方向上的变化率。若点上的输入方向为 $(\dot{u}, \dot{v})$ ，有

$$\begin{aligned} \dot{r} &= v\dot{u} + u\dot{v}, & \dot{s} &= \dot{r} + \dot{u}, \\ \dot{t} &= 2s\dot{s}, & \dot{J} &= \frac{1}{2}\dot{t}. \end{aligned} \quad (8.39)$$

圆点表示沿所选方向上的导数，不表示时间演化。取 $u = 2, v = 3$ ，前向值依次为 $r = 6, s = 8, t = 64, J = 32$ 。如果选择 $(\dot{u}, \dot{v}) = (1, 0)$ ，表示只沿 u 的正方向考察变化：乘法给出 $\dot{r} = 3$ ，加法还收到 u 直接传来的 1，于是 $\dot{s} = 4$ ；经过平方与缩放，得到 $\dot{t} = 64$ 、 $\dot{J} = 32$ 。




图 8.11 具体算子图上的前向模式。圆形节点表示乘法、加法、平方和缩放；实线上方的黑色数字是传入算子的值，下方红色数字是同一路径上的方向导数。每个算子下方再用两行列出其输出值和输出方向导数。输入方向 $(1, 0)$ 给出 $\partial J / \partial u = 32$ ；加法处的 $\dot{s} = 3 + 1$ 包含了 u 的两条路径。

图 8.11 把一次方向导数计算附在原有算子图上。若要计算对 v 的偏导，改取 $(\dot{u}, \dot{v}) = (0, 1)$ ：此时 $\dot{r} = 2$ 、 $\dot{s} = 2$ 、 $\dot{t} = 32$ ，最终 $\dot{J} = 16$ 。两次遍历的前向值相同，变化的是输入方向以及随之传播的导数。

8.2.3.2 后向模式与梯度累加

若希望从一个标量目标同时得到多个输入的导数，可以反过来问：输出对当前中间值有多敏感？**后向模式** (reverse mode) 从输出向输入累积这种敏感度。记 $\bar{r} = \partial J / \partial r$ ，对其他变量采用相同横线记号；前向值仍保留在

原算子图中，从 $\bar{J} = 1$ 开始回传：

$$\begin{aligned}\bar{t} &= \frac{1}{2}\bar{J}, \quad \bar{s} = 2s\bar{t}, \\ \bar{r} &= \bar{s}, \quad \bar{u} = \bar{r}v + \bar{s}, \\ \bar{v} &= \bar{r}u.\end{aligned}\tag{8.40}$$

每条回传贡献等于下游敏感度乘该条依赖的局部导数。缩放算子给出 $\bar{t} = 1/2$ ，平方算子利用保存的 $s = 8$ 得到 $\bar{s} = 8$ ，加法向两个输入各传递 8。其中传给 r 的 8 再经过乘法，分别给 u 和 v 贡献 $8v = 24$ 与 $8u = 16$ 。




图 8.12 同一算子图上的后向模式。节点位置与前向模式相同，实线及其黑色标注保留前向传递值，红色虚线及其标注从 $\bar{J} = 1$ 开始回传导数贡献；每个算子下方两行分别给出输出值和伴随值。输入 u 收到经乘法传来的 24 和直接经加法传来的 8，累加为 32；输入 v 得到 16。一次后向遍历同时得到两个偏导。

在图 8.12 中， u 有两条通向目标的路径，所以 $\bar{u} = 24 + 8 = 32$ 。若漏掉直接进入加法的路径，就会错误地得到 24。共享参数在多处被使用时也遵循同样规则：先保存各使用位置的局部回传贡献，再把它们累加到同一个参数。后向模式改变的是求导顺序，原函数的前向依赖并没有改变。

8.2.3.3 两种模式的计算代价

对一般映射 $\mathbf{F} : \mathbb{R}^p \rightarrow \mathbb{R}^q$ ，记雅可比为 $\mathbf{J}_F \in \mathbb{R}^{q \times p}$ 。前向模式在给定输入方向 $\mathbf{v} \in \mathbb{R}^p$ 时计算 $\mathbf{J}_F \mathbf{v}$ ，后向模式在给定输出权重 $\mathbf{u} \in \mathbb{R}^q$ 时计算 $\mathbf{J}_F^\top \mathbf{u}$ 。二者都可直接计算乘积，无需存储完整雅可比。用逐坐标方向构造完整雅可比时，前向模式需要 p 个方向，后向模式需要 q 个方向；实际代价还取决于批处理、稀疏结构和基本算子的实现。

神经网络训练通常有很多参数，却只有一个标量目标，即 $q = 1$ 。后向模式从该目标出发，能够在与前向求值同阶的算术工作中得到完整参数梯度，代价是保存或重新计算反向所需的中间值。前述反向传播就是后向模式在神经网络损失上的具体应用²⁰。

²⁰ A. G. Baydin, B. A. Pearlmutter, A. A. Radul, J. M. Siskind, *Automatic Differentiation in Machine Learning: A Survey* In Journal of Machine Learning Research, 2018, vol. 18, no. 153, pp. 1–43

如果计算图包含多条损失分支，梯度在共同上游节点相加；如果某些分支被有意停止求导，它们就不再贡献上游梯度。离散采样、取整和按值选择分支也需要分别判断可微性：自动微分通常沿当前执行路径应用已登记的规则，不会自行补上对离散选择概率的导数。正确使用自动微分仍需理解目标、连接路径与不可微操作，梯度检查只是其中一种核验手段。

8.3 理论分析

一次预测可以计算、一个目标可以求导之后，还需回答两个不同的问题：这个网络族是否包含足够好的函数，以及有限样本和具体算法能否支持低预测风险。表达性考察前一个问题，可学习性考察后一个问题。把它们分开，才能解释为什么“有一组正确参数”不是“训练一定成功”的证明。

8.3.1 表达性

前章的异或例子是一个精确表示结论：指定输入集合上存在某组参数，输出规则与标签一致。面对一般连续输入，常见问题则是能否让网络与目标函数的误差足够小。**表达性** (expressivity) 描述网络族能够表示或逼近哪些函数；它的判断对象是整类可选参数形成的函数，而不是某次训练得到的参数。

一个重要存在性结论是**通用逼近** (universal approximation)：允许适当增加网络规模时，可以逼近规定函数类中的任意目标。下面把输入限制在紧集内；在有限维实数空间中，这就是闭且有界的集合，例如 $[0, 1]^d$ 。我们要求范围内每个输入的绝对误差都小于给定精度，而不只是训练样本的平均误差小，这称为一致误差控制。定理将明确这一误差要求下允许怎样选择网络规模。

定理 8.2 单隐藏层的通用逼近 设 $X \subset \mathbb{R}^d$ 为非空紧集， $f: X \rightarrow \mathbb{R}$ 连续，激活函数 $\sigma: \mathbb{R} \rightarrow \mathbb{R}$ 连续且不是多项式。对于任意 $\varepsilon > 0$ ，存在有限宽度 m 及参数 $a_j, b_j \in \mathbb{R}$ 、 $\mathbf{w}_j \in \mathbb{R}^d$ 和 $c \in \mathbb{R}$ ，使

$$g(\mathbf{x}) = c + \sum_{j=1}^m a_j \sigma(\mathbf{w}_j^T \mathbf{x} + b_j), \quad (8.41)$$

$$\sup_{\mathbf{x} \in X} |g(\mathbf{x}) - f(\mathbf{x})| < \varepsilon.$$

这一定理是 Leshno 等关于非多项式激活结果在连续情形下的表述，隐藏层具有偏置，输出是隐藏响应的线性组合²¹。Sigmoid、Tanh、ReLU、GELU 与 SiLU 均满足这里的激活条件；ReLU 不必处处可微，因为逼近定理并没有要求求导。向量值连续目标可以逐坐标应用该结论，再组合有限个隐藏单元。

²¹ M. Leshno, V. Y. Lin, A. Pinkus, S. Schocken, *Multilayer Feedforward Networks with a Nonpolynomial Activation Function Can Approximate Any Function In Neural Networks*, 1993, vol. 6, no. 6, pp. 861–867

定理中的量词顺序是先给定 f 与 ε ，再选择宽度和参数。它没有给出一个固定宽度对所有目标都够用的结论，也没有限制参数范数、保证梯度下降找到这些参数，或规定需要多少训练样本。误差控制只覆盖 $\mathbf{X}$ ，不能据此保证域外外推。连续网络也不能在包含跳跃点的区间上，以任意小的一致误差逼近跳跃函数；改用按数据分布加权的误差，讨论对象与条件就会改变。

非线性本身也不是单隐藏层通用逼近的充分条件。例如，若激活为 $\sigma(z) = z^2$ ，不论隐藏层多宽，线性输出都是输入坐标的次数至多为 2 的多项式。固定深度的多项式激活网络也只有有界次数，不能套用上述定理。这一反例针对规定深度和输出形式；若允许深度变化，函数类也会改变。

ReLU 网络的一个直接读法是分段仿射变换。在一组隐藏单元的正负状态固定的输入区域内，所有 ReLU 都等价于保留某坐标或置零，整个网络因而是仿射的。不同激活状态形成不同区域，区域边界随参数改变。它能拼接出复杂形状，但固定有限网络仍只有有限个这样的区域。

一维情形能把这种拼接写成明确公式。设连续分段线性函数的内部转折点为 $t_1 < \dots < t_m$ ，从左到右的斜率为 $s_0, s_1, \dots, s_m$ ，则可写成

$$f(x) = c + s_0 x + \sum_{j=1}^m (s_j - s_{j-1}) \rho(x - t_j). \quad (8.42)$$

每个 ReLU 在一个转折点之后改变斜率；常数 c 确定整体高度。若标准 MLP 不含直接的线性输入支路，可以用 $x = \rho(x) - \rho(-x)$ 补出 $s_0 x$ 。因此宽度确实可以增加可表达的转折，而不只是抽象地增加参数。对紧区间上的连续函数取足够密的插值节点，再作分段线性插值，也给出了 ReLU 通用逼近在一维中的构造直觉。

深度提供另一种组织复杂函数的方式：重复复用已有变换。考虑 $[0, 1]$ 上的三角形函数

$$T(x) = 2\rho(x) - 4\rho(x - 1/2) + 2\rho(x - 1). \quad (8.43)$$

它在 $[0, 1/2]$ 从 0 上升到 1，在 $[1/2, 1]$ 再下降到 0。令 T_k 表示 T 复合 k 次，而不是 T 的 k 次幂。 T_1 有两个线性区间，每个区间都把输入完整地送到 $[0, 1]$ ；再次应用 T 就把每个区间分成两段。归纳可得 T_k 在 $[0, 1]$ 有 2^k 个线性区间。

把 T 的三个 ReLU 响应与线性组合逐次串联，可以用深度随 k 线性增长、每层宽度有常数上界的网络表示 T_k ；相邻线性映射可合并到下一层权重中。单隐藏层的一维 ReLU 网络中，每个单元至多引入一个内部转折，所以要精确表示具有 2^k 个线性区间的 T_k ，至少需要 $2^k - 1$ 个隐藏单元。图 8.13 展示了这种重复组合的效率。更一般的深度分离结果还需固定误差




图 8.13 三角形函数的复合产生更多转折。三幅解析图分别为 $T_1 = T$ 、 $T_2 = T \circ T$ 和 $T_3 = T \circ T \circ T$ ，横轴均为 $x \in [0, 1]$ ，纵轴为函数值。每次复合将线性区间数翻倍；这是一维构造，不是实际训练实验，也不表示任意目标都能从增加深度中获得相同收益。

度量、目标函数族和比较网络的范围²²。

这个例子比较的是同一目标的表示成本，并没有证明深度越大就越容易训练或越能泛化。某些目标用浅层结构已经足够；若目标本身具有可复用的组合规律，深度才可能以较少单元组织这种规律。表达能力的分析因此应同时说明目标、激活、深度、宽度和逼近精度。

²² M. Telgarsky, *Benefits of Depth in Neural Networks* In Proceedings of the 29th Annual Conference on Learning Theory, 2016, pp. 1517–1539

8.3.2 可学习性

通用逼近允许观察目标函数之后选择参数，而训练只能看到有限个样本。网络可以在这些样本之间构造许多不同的延伸，未见输入上的表现也就可能不同。**可学习性**考察给定任务、数据假设和学习方式时，样本能否支持低风险的预测规则。统计上需要多少样本、计算上能否找到合适参数，分别需要复杂度和优化方面的依据。

沿用统计学习框架，假设训练样本独立同分布地来自 $\mathcal{P}$ ，测试样本也来自同一分布。对事先确定的网络函数空间 $\mathcal{H}$ ，记期望风险为 $R(f) = \mathbb{E}_{\mathcal{P}} \ell(f(\mathbf{x}), y)$ 、经验风险为 $\hat{R}_S(f)$ ，学习算法的输出为 $\hat{f} = A(S) \in \mathcal{H}$ 。若对所有 $f \in \mathcal{H}$ 同时有 $|R(f) - \hat{R}_S(f)| \leq \Delta$ ，且算法的经验优化误差至多为 ξ ，则

$$\begin{aligned}
 R(\hat{f}) - R^* &\leq \underbrace{\inf_{f \in \mathcal{H}} R(f) - R^*}_{\text{逼近误差}} \\
 &\quad + \underbrace{2\Delta}_{\text{估计误差的控制}} + \underbrace{\xi}_{\text{优化误差}}。
 \end{aligned} \tag{8.44}$$

这里 R^* 是同一损失下允许所有可测预测规则得到的最优风险， ξ 满足 $\hat{R}_S(\hat{f}) \leq \inf_{f \in \mathcal{H}} \hat{R}_S(f) + \xi$ 。把 $\hat{f}$ 的经验风险与某个近似最优比较函数的经验风险连接起来，再分别用一致偏差 Δ 替换为期望风险，就得到该式。对于无界损失，要建立这样的统一界还需矩或尾部等额外条件。

这三项解释了增加模型规模的不同作用：更大的函数空间可能降低逼近误差，却会改变估计误差的控制；更深的计算也可能使优化误差难以降低。式(8.44)是一个有条件的风险分解，不保证某个具体界在大网络中紧，也不意味着真实测试误差必须随参数量单调增加。

输入维度通过表示规模与数据几何共同起作用。若每个坐标都满足 $|x_j| \leq c$ ，只能粗略保证 $\|\mathbf{x}\|_2 \leq c\sqrt{d}$ ，因而以输入范数为依据的界可能随 d 变大；若输入整体已归一化，或数据只占据较低维的有效区域，维度的作用就不能只按坐标数判断。但低维分布本身也不保证任务简单：标签可能在该区域内变化得很复杂，还可能含有噪声。输入分布、目标结构和损失应在同一分析中固定。

样本量的作用可以用前文已经证明的两层 ReLU 结论具体展示。此处改用标签 $y \in \{-1, +1\}$ 和标量分类得分，讨论不含偏置的函数

$$f(\mathbf{x}) = \sum_{j=1}^m a_j \rho(\mathbf{w}_j^\top \mathbf{x}), \quad \sum_{j=1}^m |a_j| \leq A, \quad \|\mathbf{w}_j\|_2 \leq B.$$

在抽样前固定 $A, B, r, \gamma > 0$ ，并假定 $\|\mathbf{x}\|_2 \leq r$ 。由第二卷“基础、理论和可信性”的“深度学习的可学习性”章“两层网络的范数与期望风险”定理，以至少 $1 - \delta$ 的概率，上述函数同时满足

$$\begin{aligned} \mathbb{P}_{\mathcal{P}}\{yf(\mathbf{x}) \leq 0\} &\leq \frac{1}{n} \sum_{i=1}^n \mathbb{I}\{y_i f(\mathbf{x}_i) \leq \gamma\} \\ &\quad + \frac{4ABr}{\gamma\sqrt{n}} + 3\sqrt{\frac{\log(2/\delta)}{2n}}. \end{aligned} \quad (8.45)$$

其中 γ 是要求训练样本达到的正分类间隔， $\delta \in (0, 1)$ 是允许保证失效的概率。左侧把零间隔也计为错误，因而可控制固定平局规则下的分类风险。右侧既包含未达到间隔的训练样本比例，也包含从有限样本推断新样本时的复杂度代价；它不只检查训练样本是否分对。

在 A, B, r, γ, δ 固定时，将样本量增至四倍，会把后两项减半。这是该充分界的缩放关系，不意味着实际测试错误率一定减半。它也说明为什么要区分独立样本与重复记录：把同一条记录复制四次没有产生这项独立同分布保证所要求的新信息。

参数范数与间隔需要一起看。把所有输出权重乘以一个很小的正数，会缩小 A ，但也按相同比例缩小分类间隔，分类符号并不改变；因此不能由权重变小直接推出分类风险变小。若在保持函数不变的前提下，将某个 ReLU 隐藏单元的输入权重乘 $c > 0$ 、输出权重除以 c ，不同层的原始范数同样会变化。分析应采用与函数、间隔及参数化相配的复杂度量。

式(8.45)没有显式出现隐藏宽度 m ，因为总输出权重和各隐藏权重范数

已经受到限制。增加宽度可以提供更多候选特征，却不能无限放大所有特征。如果宽度增加时 A 、 B 也增加，或有效间隔变小，界仍会变差。允许所有宽度和任意权重的分类函数空间又可能具有无限 VC 维，不能把这条有范数与间隔条件的保证推广为整个网络族的分布无关 PAC 保证。固定有限 ReLU 架构的 VC 分析及其统计学习结论见第二卷“基础、理论和可信性”的“深度学习的可学习性”章。

深度影响层间扰动的放大。对本章的串联网络，若隐藏激活均为 1-Lipschitz，即不会增大两点之间的欧氏距离，原始输出映射满足

$$\|\mathbf{a}(\mathbf{x}) - \mathbf{a}(\mathbf{x}')\|_2 \leq \left(\prod_{\ell=1}^{L+1} \|\mathbf{W}_\ell\|_2 \right) \|\mathbf{x} - \mathbf{x}'\|_2. \quad (8.46)$$

这里矩阵谱范数 $\|\mathbf{W}_\ell\|_2$ 表示线性变换对向量长度的最大放大倍数。每层分别使用这一上界，再沿函数复合相乘，便得到该式；有其他 Lipschitz 常数的激活还需乘上相应因子。偏置在比较同一层的两个输入时相消，但它仍会影响激活区域及函数空间的复杂度。

式(8.46)控制固定网络的输入敏感度，不能单独给出泛化保证。深层谱复杂度分析还结合各层其他范数、输入尺度和分类间隔，具体条件见第二卷“基础、理论和可信性”的“深度学习的可学习性”章“基于参数大小的可学习性”节。它说明深度不能只作为层数进入判断：层间尺度的乘积、可复用目标结构以及训练能否得到合适表示，都可能同时变化。

学习算法决定从许多低训练损失参数中选择哪一个解。第二卷“基础、理论和可信性”的“深度学习的可学习性”章“基于参数梯度更新的可学习性”节讨论的选解偏好，第二卷“基础、理论和可信性”的“深度学习的可学习性”章“基于参数梯度初始值的可学习性”节讨论的初始梯度特征，分别在规定条件下描述这种选择。初始化、更新方式、正则化和停止时刻既可能影响经验优化误差，也可能影响输出对样本替换的敏感性。若算法具有损失均匀稳定性 β_n ，其期望泛化差可受 β_n 控制；这条结论比较的是更换训练样本后的两个训练结果，不能用同一次训练中两次参数更新很接近来代替。

因此，从前馈结构得到学习判断，需要把任务、样本分布、候选函数约束和算法放在一起。独立同分布风险界不直接覆盖部署分布改变，交叉熵降低也不直接等于零一风险保证。一个完整论证应当说明网络能逼近什么、样本支持多强的估计、算法能将经验目标降到哪里，以及这些条件如何共同转成所关心的预测风险。

8.4 常见应用

前馈网络既可以完成固定长度输入的预测，也可以在更大的模型中承担一段变换。应用时需要明确它接收什么表示、输出什么对象、由哪个损失训练。仅给出隐藏层的形状，还不能得到完整的预测方法。

8.4.1 表格数据的分类与回归

表格中的一行通常描述一个对象，不同列分别记录数值或类别属性。网络接收的是定长数值向量，所以必须先规定每列怎样进入向量。数值列可按训练集统计量标准化，类别列可编码成互斥的指示坐标，缺失值则需规定填充值并酌情加入缺失标记。这些规则也属于模型使用过程：验证集、测试集和新样本使用训练阶段已经确定的转换，不重新用测试数据估计均值和方差。

考虑一个教学任务：由设备使用时长、近期告警次数和三个设备类别之一，预测下一段时间是否发生故障。设两个数值变量标准化为 $\tilde{x}_1, \tilde{x}_2$ ，设备类别编码为 $\mathbf{c} \in \{0, 1\}^3$ 且坐标和为 1，输入为

$$\mathbf{x} = (\tilde{x}_1, \tilde{x}_2, c_1, c_2, c_3)^\top \in \mathbb{R}^5。$$

采用宽度为 16 和 8 的两个 ReLU 隐藏层、一个标量输出，可以把完整模型写为

$$\begin{aligned} \mathbf{h}^{(1)} &= \rho(\mathbf{W}_1 \mathbf{x} + \mathbf{b}_1), \\ \mathbf{h}^{(2)} &= \rho(\mathbf{W}_2 \mathbf{h}^{(1)} + \mathbf{b}_2), \\ p &= s(\mathbf{w}_3^\top \mathbf{h}^{(2)} + b_3)。 \end{aligned} \tag{8.47}$$

其中 $\mathbf{W}_1 \in \mathbb{R}^{16 \times 5}$ 、 $\mathbf{W}_2 \in \mathbb{R}^{8 \times 16}$ 、 $\mathbf{w}_3 \in \mathbb{R}^8$ ，偏置维度与对应输出相同。这组层宽是示例设计，不是经过实验验证的推荐配置。

训练标签 $y \in \{0, 1\}$ 记录指定时间窗内是否发生故障，用二元交叉熵构造式(8.28)，再按算法 8.1 学习参数。输入必须只包含预测时刻已知的信息；故障发生后记录的维修结果不能作为预测前的输入。若同一设备有多条记录，还需按设备和时间等关系划分数据，使评价符合预期部署场景。

预测新设备记录时，先按保存的规则得到 $\mathbf{x}$ ，再计算 p ，根据验证阶段确定的决策阈值得到类别。若任务改为预测后续维修时长 $y \in \mathbb{R}$ ，可保留输入编码与隐藏层，改用线性输出和平方损失；若必须保证非负预测，可增加相应输出约束。改变输出和损失是在改变预测对象，不能只把故障标签换成一个数值而保留原来的概率解释。

全连接结构允许数值与类别特征在隐藏层共同作用，但它没有自动规定某种单调关系，也没有保证类别编码在缺少样本时得到可靠估计。类别很多时，直接增加指示坐标还会扩大第一层参数量，可以考虑用可学习的

低维向量表示类别，但这种表示同样需要训练数据支持。对表格任务，应与适合任务的简单模型比较，并依据独立评价选择模型；架构名称不能替代数据与误差分析。

8.4.2 其他网络中的前馈模块

当输入表示已经由其他模型得到时，前馈网络仍可以把它投影到新空间，或转换成任务输出。**特征投影**（feature projection）改变表示的维度或坐标组织，例如用 $\mathbf{W}\mathbf{h} + \mathbf{b}$ 把 d 维向量映射到 q 维。若只是两次线性投影且中间没有非线性，它们仍可以合并为一次仿射映射；如果中间维度较小，这种参数化还会限制整体线性映射的秩。

分类头（classification head）是把已有表示转换为类别得分的末端模块。卷积编码器可以把图像压成一个向量，再接线性层或 MLP 得到类别得分。联合训练时，分类损失的梯度沿前馈模块继续传到编码器；若固定编码器，只更新分类头，学习的参数范围就缩小了。同一个模块形状可以对应不同训练过程，应明确哪些参数参与更新。

有时模块输出的是两个对象的相关性或匹配程度。例如，将两个 d 维表示 $\mathbf{u}, \mathbf{v}$ 拼接，构成输入 $[\mathbf{u}; \mathbf{v}] \in \mathbb{R}^{2d}$ ，再计算

$$\text{score}(\mathbf{u}, \mathbf{v}) = \mathbf{w}^\top \sigma(\mathbf{W}[\mathbf{u}; \mathbf{v}] + \mathbf{b}) + c. \quad (8.48)$$

其中隐藏宽度为 m ， $\mathbf{W} \in \mathbb{R}^{m \times 2d}$ 、 $\mathbf{b}, \mathbf{w} \in \mathbb{R}^m$ 、 $c \in \mathbb{R}$ 。这个**评分函数**（scoring function）把对象表示转换为标量得分，概率变换和损失由匹配或排序任务决定。拼接顺序意味着交换两个输入可能改变得分；若任务要求对称性，需要在输入或计算结构中加入相应约束。

前馈模块也可以对一组位置重复使用。设第 t 个位置的表示为 $\mathbf{h}_t \in \mathbb{R}^d$ ，用同一组参数计算

$$\text{FFN}(\mathbf{h}_t) = \mathbf{W}_2 \sigma(\mathbf{W}_1 \mathbf{h}_t + \mathbf{b}_1) + \mathbf{b}_2, \quad (8.49)$$

其中 $\mathbf{W}_1 \in \mathbb{R}^{m \times d}$ 、 $\mathbf{W}_2 \in \mathbb{R}^{d \times m}$ ，偏置维度与相应输出一致。这种**逐位置变换**（position-wise transformation）分别改变每个位置内部的特征组合，在 Transformer 等模型中作为一个模块使用。它读取的 $\mathbf{h}_t$ 可以已经包含其他位置的信息，但这次变换本身不读取 $\mathbf{h}_{t'}$ ，因而不直接建立新的跨位置交互。

位置共享参数意味着所有位置的梯度都要累积到同一组 $\mathbf{W}_1, \mathbf{W}_2$ ，而不是为每个位置保存一份独立参数。这个例子也区分了网络名称与模块职责：更大的模型可以包含前馈计算，前馈模块负责特征变换，其他结构负责空间、序列或对象之间的信息交换。后续各模型章会在这一基础上讨论相应的结构假设。

8.5 本章小结

前馈神经网络把可学习表示落实为一条没有有向环的计算路径。全连接层组合已有坐标，非线性激活让多层复合超出仿射映射，输出变换与损失共同规定训练所要预测的对象。选择层宽和激活时，既要能形成怎样的函数，也要看参数量、计算量和梯度传播条件。

隐藏层的学习信号来自最终目标对它的敏感度。反向传播按链式法则逐层汇总这种影响，用局部导数和已有活动值计算所有参数梯度；自动微分将同样的原则推广到程序的实际计算路径。初始化决定起点，优化器使用梯度作出更新，二者都影响学习结果，正确求导只是完成训练的一个条件。

能够逼近目标函数、能够优化经验目标、能够用有限样本控制预测风险，仍是三个不同的要求。通用逼近解释存在怎样的参数，深度与宽度解释表示成本，复杂度和稳定性则在数据与算法条件下连接训练结果和新样本风险。前馈网络适合处理定长表示，也可作为投影、分类、评分和逐位置变换模块；遇到具有明确空间、序列或关系结构的数据时，还需判断全连接假设是否充分利用了这些规律。后续章节将在相应结构上继续建立模型。

卷积神经网络

第8章建立了用多层非线性变换学习表示的方法。若输入是一张图像，直接把像素排成向量送入全连接层，这种方法依然能够计算，但图像中相邻像素的关系不会自动体现在连接中。更具体地说，左上角与右下角出现的同一种边缘，需要由不同权重分别识别。怎样让网络利用图像的空间结构，并把在一个位置学到的规则用于其他位置？

本章围绕这个问题考察卷积神经网络。卷积运算规定局部信息如何组合，层与模块的组织决定这些局部结果如何形成整体预测，参数学习则让同一组权重汇集各个位置的训练信号。增加深度后，还需要解释信息与梯度怎样跨层传播，以及结构假设在什么数据条件下有助于泛化。分割与着色两个例子将把这些问题接回具有空间结构的输出。所需的激活函数、损失和链式法则沿用前章，统计分析承接第二卷“基础、理论和可信性”的“深度学习的可学习性”章。

9.1 卷积神经网络概述

设一张彩色图像有 224×224 个像素，每个像素包含三个颜色数值。展平后，输入维度为 150528；连接到 1024 个隐藏单元的全连接层，仅权重就有 154140672 个。这个教学计算说明，高维输入会迅速增大连接规模。但连接数只是一个方面：全连接层允许任意两个坐标交互，却没有预先区分相邻像素和相隔很远的像素，也没有要求不同位置用相同方式处理局部图案。

图像中的边缘可以由邻近像素的变化来辨认，而且同一种变化可能出现在许多位置。这使两项约束具有解释价值。**局部感受野** (local receptive field) 让一个单元只读取输入中的一个邻域，即把一次计算限定在附近的若干位置。**参数共享** (parameter sharing) 让不同位置使用同一组权重，即将同一种局部识别规则重复应用到整张图像。只使用局部连接而不共享参数，仍然需要为不同位置学习不同规则；两项设计承担不同职责。

卷积神经网络 (convolutional neural network, CNN) 把这种共享的局部计算与非线性变换逐层组合，从数据中学习局部特征及其组合。每个位置

并列保存的不同特征称为**通道** (channel); 彩色图像的红、绿、蓝三个分量就是三个输入通道。一个输出通道是一种局部响应在所有输出位置组成的数值平面。普通密集卷积中, 每种响应使用一组覆盖全部输入通道的权重, 因此 64 个输出通道需要 64 组权重, 而不是指 64 个空间位置。

对三个输入通道、64 个输出通道的 3×3 卷积层, 每组权重在三个输入平面上各覆盖一个 3×3 窗口, 权重总数为 $3 \times 3 \times 3 \times 64 = 1728$, 再加每个输出通道一个偏置, 共 64 个。这个层与前述全连接层的输出组织不同, 不能仅按参数量判断谁更有表达能力; 它说明的是, 卷积参数量可以不随输入图像的高和宽增加, 而同一组参数会在更多位置被使用。

共享局部规则带来一种与位置变化有关的性质。**平移等变性** (translation equivariance) 表示输入移到哪里, 输出中的对应响应也移到哪里。**平移不变性** (translation invariance) 则表示输入平移后, 输出本身保持相同。图像分类可能希望物体移动后类别不变, 分割却需要轮廓随物体移动, 因而需要保留位置对应关系。步长为一的卷积在无限网格上与平移可交换; 有限图像的边界、下采样和最终读出会改变这一性质。全局汇聚可以在适当条件下得到不变输出, 但卷积层本身并不自动完成这一转换。

这些设计适合具有规则网格、局部相关性和重复模式的数据。图像使用二维邻域, 音频波形和时间序列可以使用一维邻域, 体数据可以使用三维邻域。时间预测还需限制可读取的位置, 避免使用尚未发生的输入。若各坐标只是含义不同的表格字段, 交换相邻字段通常会改变含义, 同一个局部规则也未必能沿字段排列重复使用。卷积的适用性取决于这些结构是否与任务相符。

局部处理与逐层汇聚的思想早于今天的大规模深度学习。Fukushima 于 1980 年提出的 Neocognitron 交替组织局部模式检测与汇聚, 使高层能够组合低层响应, 并容忍一定的位置变化。它借鉴视觉系统的分层处理, 但采用的学习机制与今天端到端反向传播的 CNN 不同; 第 7.2.2 节已介绍这条视觉启发线索¹。到 20 世纪 90 年代, LeCun 等将可学习卷积、降采样和梯度学习结合, 用于手写字符和文档识别。1998 年的 LeNet-5 展示了从像素到类别联合学习的完整系统: 局部特征由任务损失训练, 而不是先由人工固定。这一时期已经出现多层卷积网络, 却还不能据此认为大规模视觉任务的训练条件已经成熟²。

卷积结构解决了连接组织问题, 深层网络能否有效训练仍是另一道关口。2006 年, Hinton、Osindero 和 Teh 提出深度信念网络的逐层学习方法: 先学习一层隐表示, 再把该表示作为下一层的训练数据, 并对整个生成模型作后续微调。**逐层预训练**就是先分别为各层寻找有用的初始表示, 减少从随机参数同时训练全部层的困难。这项工作为研究深层表示提供了可操作的训练途径, 是理解随后深度学习兴起的一项重要进展。它研究的是生成式深层模型, 原文的微调采用对比形式的 wake-sleep 算法, 与后来判别

¹ K. Fukushima, *Neocognitron: A Self-Organizing Neural Network Model for a Mechanism of Pattern Recognition Unaffected by Shift in Position* In *Biological Cybernetics*, 1980, vol. 36, no. 4, pp. 193–202

² Y. LeCun, L. Bottou, Y. Bengio, P. Haffner, *Gradient-Based Learning Applied to Document Recognition* In *Proceedings of the IEEE*, 1998, vol. 86, no. 11, pp. 2278–2324

式 CNN 的直接监督训练具有不同的目标和步骤³。

另一条路线继续探索直接用监督信号训练卷积网络。GPU 能够并行执行大量规则相加，使更宽、更深的模型获得实际可用的训练速度。Cireşan 等在 2011 年报告了 GPU 上的可配置卷积网络，并在多个图像识别数据集上研究直接反向传播训练。这说明 2012 年的突破有此前的计算与训练积累，GPU 卷积并非在 AlexNet 中才首次出现⁴。更大的有标签数据集又让网络可以学习更丰富的视觉变化；模型结构、训练方法、数据规模和计算资源需要同时匹配，单独增加层数并不足以重现这种进展。

2012 年，AlexNet 在 ImageNet 大规模图像分类中将五个卷积层、ReLU、GPU 训练、数据增强和全连接层中的 Dropout 组合起来，以监督学习从像素学习类别判别。论文报告的 ILSVRC-2012 参赛系统取得 15.3% 的 top-5 测试错误率，第二名为 26.2%；这里的 top-5 错误指正确类别未进入前五个预测。15.3% 对应多个网络的组合，并包含额外 ImageNet 数据预训练；它衡量的是这套参赛系统，单个网络的误差另有报告。这个结果清楚展示了大规模学习特征相对于当时参赛方案的优势，推动卷积网络成为视觉研究的重要路线。这里的预训练是在更大标签集上的监督训练，与 2006 年的逐层生成式预训练不同⁵。

此后的架构发展把问题进一步拆开：VGG 用连续小核组织深度，GoogLeNet 用多分支与通道压缩分配计算，Highway 和 ResNet 为跨层信息提供路径，DenseNet 让后层直接复用旧特征。它们将在本章相应小节中展开。把这段历史连起来，CNN 的发展既包含“如何利用空间结构”的持续改进，也包含“如何让深层表示学得出来”的训练进展；深度学习的兴起是这些进展与数据、计算条件共同作用的结果。

9.2 卷积运算

局部规则需要一个明确的计算形式：在每个位置读取哪些输入，每个输入乘什么权重，结果怎样相加。数学卷积提供了这一形式；网络实现则会调整核的方向、边界和采样方式。本节先固定运算含义，再用同一组数值检查这些调整。

³ G. E. Hinton, S. Osindero, Y.-W. Teh, *A Fast Learning Algorithm for Deep Belief Nets* In *Neural Computation*, 2006, vol. 18, no. 7, pp. 1527–1554

⁴ D. C. Cireşan, U. Meier, J. Masci, L. M. Gambardella, J. Schmidhuber, *Flexible, High Performance Convolutional Neural Networks for Image Classification* In *Proceedings of the Twenty-Second International Joint Conference on Artificial Intelligence*, 2011, pp. 1237–1242

⁵ A. Krizhevsky, I. Sutskever, G. E. Hinton, *ImageNet Classification with Deep Convolutional Neural Networks* In *Advances in Neural Information Processing Systems 25*, 2012, pp. 1097–1105

9.2.1 卷积的定义

在一维信号中，一个时刻的结果可以由周围时刻的输入加权形成。**连续卷积** (continuous convolution) 用积分累积这些贡献，定义时需要指定输入的定义域、核的方向和积分存在的条件。

定义 9.1 连续卷积 设 $d \geq 1$, $f, g \in L^1(\mathbb{R}^d)$, 即二者在 $\mathbb{R}^d$ 上绝对可积。它们的卷积 $f * g$ 定义为

$$(f * g)(t) = \int_{\mathbb{R}^d} f(\tau)g(t - \tau) d\tau, \quad (9.1)$$

该积分几乎处处存在，且 $f * g \in L^1(\mathbb{R}^d)$ 。

当 $d = 1$ 时，式中 t, τ 改为标量 t, τ ，积分范围是整条实数轴。 t 是输出位置， τ 遍历输入位置， $g(t - \tau)$ 给出输入 $f(\tau)$ 在该位置的权重。作为 τ 的函数， $g(t - \tau)$ 可由 $g(\tau)$ 翻转后再平移得到。积分将重叠位置上的乘积累积成一个数值；移动 t 便得到整条输出信号。绝对可积条件保证这个定义成立，不要求两个函数处处连续。

二维数组中的翻转要同时反转核的行、列顺序，相当于旋转 180 度。省去翻转会怎样改变输出，第 9.2.2.1 节和图 9.1 将用同一输入窗口直接比较。

离散卷积 (discrete convolution) 把积分换成网格上的求和。记 $\ell^1(\mathbb{Z}^d)$ 为满足 $\sum_{i \in \mathbb{Z}^d} |x_i| < \infty$ 的序列空间，整数向量 i 标识网格位置。

定义 9.2 离散卷积 对 $x, k \in \ell^1(\mathbb{Z}^d)$ ，其离散卷积为

$$(x * k)_i = \sum_{a \in \mathbb{Z}^d} x_a k_{i-a} = \sum_{a \in \mathbb{Z}^d} k_a x_{i-a}. \quad (9.2)$$

所有位置的求和绝对收敛，且 $x * k \in \ell^1(\mathbb{Z}^d)$ 。 k 称为**卷积核** (convolution kernel)，它规定不同相对位置的加权方式。

一维时把向量索引简写为 i, a ，二维时展开为 $(i, j), (a, b)$ 。若核只有有限个非零元素，每个输出仅需有限次乘加，因而也可对不绝对可和的输入逐点定义。取 $k_0 = k_1 = 1/2$ 、其余为零，有 $y_i = (x_i + x_{i-1})/2$ ：输出是当前值与前一时刻值的平均。核的索引方向决定使用过去还是未来的输入。有限长度输入和核可在定义域外补零，此时完整一维卷积的支撑长度至多为 $n_x + n_k - 1$ ；裁去两端所得的短输出是完整卷积的一个选段。

有限信号还可以采用周期边界，此时使用**循环卷积** (circular convolution)，越过末端的位置会按周期返回原序列。

定义 9.3 循环卷积 对长度为 n 的序列 $\mathbf{x}, \mathbf{k} \in \mathbb{R}^n$, 循环卷积为

$$(\mathbf{x} *_n \mathbf{k})_i = \sum_{a=0}^{n-1} x_a k_{(i-a) \bmod n}, \quad i = 0, \dots, n-1. \quad (9.3)$$

下标按模 n 返回原序列, 等价于先作周期延拓, 再在一个周期上求和。

循环卷积保留 n 个输出, 越过末端的贡献会回到开头。零延拓的线性卷积则让这些贡献留在更长的输出中。这一区别将直接影响 FFT 实现的补零与裁剪。

卷积对每个输入分别具有线性性。例如, 对标量 α, β 及序列 x, z ,

$$(\alpha x + \beta z) * k = \alpha(x * k) + \beta(z * k). \quad (9.4)$$

在上述绝对可和条件下, 卷积还满足交换律 $x * k = k * x$ 和结合律 $(x * k) * g = x * (k * g)$ 。交换律可通过把求和变量 a 改为 $i - a$ 得到; 结合律依赖双重求和可以交换次序。有限支撑序列天然满足这些条件。这些性质针对完整的数学卷积, 插入裁剪、跨步或非线性后, 不能直接沿用。

平移性质同样可以由换元看出。记 $(T_r x)_i = x_{i-r}$, 即将序列平移整数 r 个位置, 则

$$(T_r x) * k = T_r(x * k). \quad (9.5)$$

这条等式比较的是同一组核权重下的两个输出, 解释了参数共享与平移等变性的联系。多个线性卷积可以合并成一个有效卷积核; 网络在层间加入激活, 才使这种逐层组合超出单次线性滤波。

这一定义还解释了卷积为什么适合表示共享局部规则。设 L 是定义在有限支撑序列上的线性算子, 并满足 $L(T_r x) = T_r(Lx)$ 。令 δ 为仅在零位置取一的单位脉冲, 记 $k = L\delta$ 。任意有限支撑输入都可写成 $x = \sum_a x_a T_a \delta$, 于是

$$Lx = \sum_a x_a T_a (L\delta) = \sum_a x_a T_a k = x * k. \quad (9.6)$$

换言之, 线性性与对所有整数平移的等变性共同确定了卷积形式; k 就是系统对单位脉冲的响应。这里限制输入为有限支撑, 避免无穷级数还需额外连续性假设的问题。有限图像的裁剪和跨步不一定满足同样的平移条件。

卷积的物理意义可以从“输入引起响应, 响应随时间展开”来理解。设一个理想化的蓄水装置收到一升水后, 当日排出 0.5 升, 次日排出 0.3 升, 再下一日排出 0.2 升。假设排水量与进水量成正比, 而且同一升水在不同日期进入, 排水规律只随之平移。核 $k = (0.5, 0.3, 0.2)$ 就是单位输入的响

应: k_a 表示输入发生后第 a 天释放的比例。某日总排水量则是此前各次进水在这一天产生的贡献之和, 即 $y_i = \sum_a x_a k_{i-a}$ 。下标 $i-a$ 表示“距离第 a 天进水已经过去多久”, 这正是卷积中相对位置的含义。

例如, 令第零天进水 10 升、第一天为零、第二天进水 20 升, 其余日期也为零。第零天排出 $10 \times 0.5 = 5$ 升, 第一天为 $10 \times 0.3 = 3$ 升; 第二天同时收到两次进水的贡献, 为 $10 \times 0.2 + 20 \times 0.5 = 12$ 升。完整结果为

$$(10, 0, 20) * (0.5, 0.3, 0.2) = (5, 3, 12, 6, 4). \quad (9.7)$$

输出之和仍为 30 升, 因为这里的核系数非负且和为一, 所有进水最终排出。连续时间中, 每个瞬间的输入都贡献一条延迟的响应, 累积求和相应变为式(9.1)中的积分。这个例子依赖线性叠加和响应规律不随日期改变; 实际装置若溢流或流速随水位变化, 就不能直接用一个固定核描述。图像模糊也有类似读法: 一个亮点扩散成一小片亮斑, 整张图像的模糊结果由各亮点的平移响应叠加形成。CNN 沿用这种共享局部响应的结构, 但核由训练学习, 可以含负权重, 不必表示守恒的物理过程。

9.2.2 实际应用中的卷积

9.2.2.1 矩阵卷积: 翻转与局部求和

二维数据把单个位置扩展为行、列两个索引。本节采用从零开始的空间索引, 输入矩阵为 $\mathbf{X} \in \mathbb{R}^{h \times w}$, 核为 $\mathbf{K} \in \mathbb{R}^{k_h \times k_w}$, 元素分别记为 $x_{i,j}$ 和 $k_{a,b}$ 。核索引 a, b 也从零开始。完整二维数学卷积写为

$$y_{i,j} = \sum_{a=0}^{k_h-1} \sum_{b=0}^{k_w-1} k_{a,b} x_{i-a, j-b}. \quad (9.8)$$

输入在原矩阵以外如何取值, 需要另行约定。若只保留核完全落在输入内的位置, 将输出重排成从零开始的索引, 相当于先把核旋转 180 度, 再在输入上滑动, 对每个窗口作逐元素乘积和求和。

用以下教学矩阵固定输入与权重:

$$\mathbf{X} = \begin{bmatrix} 1 & 2 & 3 & 4 \\ 5 & 6 & 7 & 8 \\ 9 & 10 & 11 & 12 \\ 13 & 14 & 15 & 16 \end{bmatrix}, \quad \mathbf{K} = \begin{bmatrix} 1 & 0 \\ 0 & -1 \end{bmatrix}. \quad (9.9)$$

图 9.1 把同一窗口的两种运算并排比较。旋转后的核为 $\begin{bmatrix} -1 & 0 \\ 0 & 1 \end{bmatrix}$, 左上窗口给出 $-1 + 6 = 5$ 。步长为一旦不填充时, 核有 3×3 个合法位置, 这里的每个数学卷积输出都是 5。




图 9.1 核的方向改变输出。输入窗口固定为 $\begin{bmatrix} 1 & 2 \\ 5 & 6 \end{bmatrix}$ ，核固定为 $\begin{bmatrix} 1 & 0 \\ 0 & -1 \end{bmatrix}$ 。左侧直接逐元素相乘后求和，得到互相关输出 -5；右侧先把核旋转 180 度，再求和，得到数学卷积输出 5。 $\odot$ 表示逐元素乘法， Σ 表示把四个乘积相加。

9.2.2.2 互相关：保留核的方向

网络通常省去这次旋转，直接用存储的核权重对窗口求和。这种**互相关**（cross-correlation）是按核原有方向匹配局部输入；本章针对实数数据写为

$$y_{i,j} = \sum_{a=0}^{k_h-1} \sum_{b=0}^{k_w-1} k_{a,b} x_{i+a,j+b} \quad (9.10)$$

于是左上窗口得到 $1 - 6 = -5$ ，全部输出构成 3×3 的常数矩阵，见图 9.2。对无方向约束的可学习核，翻转只是参数位置的重新排列，卷积与互相关对应同一类候选映射；对预先给定的核，方向仍会改变结果。深度学习文献和软件通常把这种互相关也称为卷积。下文的网络公式遵循这一惯例，保留“数学卷积”来指明需要翻转的运算。




图 9.2 共享核在二维矩阵上滑动的教学例子。蓝色实线和虚线分别框出相邻的两个 2×2 输入窗口，红色矩阵为不翻转的核，黄色矩阵为互相关输出。每个输出计算窗口左上数值减去右下数值，因此均为 -5；两个位置使用同一组权重。

9.2.2.3 数据填充：确定边界假设

不填充时，边缘像素参与的窗口较少，输出尺寸也会缩小。**数据填充** (padding) 在矩阵外补充数值，使核可以覆盖边缘附近的位置。零填充把外部值设为零；复制填充延续最近的边缘值；反射填充按边界镜像取值；循环填充把另一侧的数据接过来。这些方式改变边界假设，不能恢复未观测的图像内容。

对式(9.9)只在右侧和下侧各补一列、一行零，输出就有 4×4 个位置：

$$Y = \begin{bmatrix} -5 & -5 & -5 & 4 \\ -5 & -5 & -5 & 8 \\ -5 & -5 & -5 & 12 \\ 13 & 14 & 15 & 16 \end{bmatrix} \quad (9.11)$$

最后一列和最后一行改变，是因为核的负权重落到了补零区域。图 9.3 标出右上和右下两个窗口：相同的核在内部读取真实数值，在边界则读取约定的零。**valid 填充** 表示不添加边界值，**same 填充** 通常表示按输入尺寸和步长选择填充，使输出尺寸达到约定值。步长为一时常取输出与输入等大；偶数核可能需要不对称填充，本例就是这种情况。步长大于一时，有些接口以 $\lceil h/s_h \rceil$ 为目标高度，具体左右分配还需核对所用约定。




图 9.3 不对称零填充与边界输出。蓝色框内是原 4×4 输入，浅红色区域是右侧、下侧各新增的一列、一行零。红色实线窗口产生右上输出 4，虚线窗口产生右下输出 16，输出矩阵中用相同线型标记对应位置。核为 $(1, 0; 0, -1)$ ，步长一、空洞率一，计算采用互相关。

9.2.2.4 跨步卷积：改变窗口移动间隔

填充改变可读取的位置，**跨步卷积** (strided convolution) 则改变输出位置之间的间隔：核每次沿高、宽分别移动 s_h, s_w 个输入位置。在原例中，不填充且 $s_h = s_w = 2$ ，只保留窗口起点 $(0, 0), (0, 2), (2, 0), (2, 2)$ ，得到 2×2 的输出，数值仍均为 -5 。图 9.4 显示，减少的是窗口起点的数量，窗口内部仍读取相邻的四个元素。它同时完成局部变换与下采样；若输入包含较

快的空间变化，下采样可能把不同变化混在一起，这就是采样中的混叠问题。




图 9.4 跨步改变输出位置的密度。输入、 2×2 核和无填充设置保持不变，只将高、宽步长从一改为二。每个蓝色圆点标记一个窗口的左上起点，起点分别形成 3×3 和 2×2 的网格；实线框只画出第一个窗口。该教学矩阵的所有窗口都得到 -5 ，输出值相同不表示读取的位置相同。

9.2.2.5 空洞卷积：改变核内采样间隔

若希望扩大一个输出所覆盖的区域，又不增加核参数，可以让核内部的采样点隔开。**空洞卷积**(dilated convolution)在相邻核元素之间跳过 $d_h - 1, d_w - 1$ 个输入位置， d_h, d_w 称为空洞率。原例取 $d_h = d_w = 2$ 、步长为一且不填充，左上输出变为 $x_{0,0} - x_{2,2} = 1 - 11 = -10$ ，得到 2×2 的常数输出。四个核位置覆盖 3×3 区域，却只采样其中四点。图 9.5 把权重与这些位置对应起来；图 9.6 再并排区分核内采样间隔与窗口移动间隔。重复使用相同空洞率还可能留下未充分交互的网格位置，扩大覆盖范围不等于密集读取其中所有信息。




图 9.5 空洞率二时的实际采样位置。左图紫框标出左上输出读取的四格，蓝色外框标出其 3×3 覆盖区域；中图把原 2×2 核权重按采样间隔排开，点号表示跳过的位置。零权重仍是核参数，点号不是新增权重。步长一、无填充时，左上输出为 $1 - 11 = -10$ ，全部输出构成 2×2 矩阵。

9.2.2.6 统一表达与输出尺寸

把这些设置合在一起，记上下填充为 p_t, p_b 、左右填充为 p_l, p_r ，以 $\tilde{x}_{i,j}$ 表示在原坐标外扩展的输入值。互相关计算为

$$y_{i,j} = \sum_{a=0}^{k_h-1} \sum_{b=0}^{k_w-1} k_{a,b} \tilde{x}_{is_h-p_t+ad_h, js_w-p_l+bd_w} \quad (9.12)$$

有效核尺寸为 $e_h = d_h(k_h - 1) + 1$ 、 $e_w = d_w(k_w - 1) + 1$ ，要求填充后的输入至少容纳一个窗口。使用只保留完整窗口的取整规则时，输出尺寸为

$$\begin{aligned} h' &= \left\lfloor \frac{h + p_t + p_b - e_h}{s_h} \right\rfloor + 1, \\ w' &= \left\lfloor \frac{w + p_l + p_r - e_w}{s_w} \right\rfloor + 1. \end{aligned} \quad (9.13)$$

分子表示窗口起点可以移动的总距离，除以步长后取整得到可移动的次数，再加上起始窗口。这也解释了为什么同样的输出大小可能来自不同的输入大小：不足一个步长的尾部会被舍去。




图 9.6 同一个 2×2 核的三种采样设置。实线框给出一个输出所覆盖的区域，紫点是该窗口实际读取的位置，虚线框表示下一个水平窗口。普通设置与跨步设置的核内邻距均为一，后者将窗口起点移远；空洞设置将核内邻距增为二，窗口起点仍只移动一格。

9.2.2.7 转置卷积：把局部贡献分配回去

卷积也可以用矩阵表达。固定核与输入、输出形状，把输入和输出展平为 $\mathbf{x}$ 和 $\mathbf{y}$ ，忽略偏置，有 $\mathbf{y} = \mathbf{C}\mathbf{x}$ ； $\mathbf{C}$ 每行对应一个输出，非零位置表示它读取哪些输入，共享权重在多行重复出现。**转置卷积** (transposed convolution) 使用这个映射的转置，即对给定 $\mathbf{v}$ 计算 $\mathbf{C}^T \mathbf{v}$ ，将一个输入值按核权重分配到多个输出位置，并把重叠贡献相加。

取原例第一行 (1, 2, 3, 4)，用一维核 (1, -1) 说明同样的过程。步长为一

且不填充时,

$$\mathbf{C} = \begin{bmatrix} 1 & -1 & 0 & 0 \\ 0 & 1 & -1 & 0 \\ 0 & 0 & 1 & -1 \end{bmatrix}, \quad \mathbf{C}^T \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix} = \begin{bmatrix} 1 \\ 0 \\ 0 \\ -1 \end{bmatrix}. \quad (9.14)$$

图 9.7 将每个输入产生的贡献分开画出。中间两个位置的贡献相消, 表明转置运算需要累加, 不能只把数值放大或复制。 $\mathbf{C}$ 把四维输入变成三维输出, 已丢失某些信息; $\mathbf{C}^T \mathbf{C}$ 也不等于单位矩阵。转置卷积因此不是逆卷积, 不能保证还原原输入。作为可学习层时, 它可以使用自己的核参数, 并不要求与编码器的核绑定。




图 9.7 转置卷积的分配与累加。输入为 $\mathbf{v} = (1, 1, 1)^T$, 核为 $(1, -1)$, 步长一、无填充。每行分别表示一个输入值对四个输出位置的贡献, 紫框圈出两个可能非零的位置; 没有贡献的格子记为零。逐列相加得到 $(1, 0, 0, -1)^T$, 中间两格均包含来自不同输入的重叠贡献。

在一维对称零填充 p 、步长 s 、空洞率 d 和核长 k 的约定下, 转置卷积输入长度 n' 对应的输出长度常写为

$$n_{\text{out}} = (n' - 1)s - 2p + d(k - 1) + 1 + o, \quad 0 \leq o < s. \quad (9.15)$$

这里 o 是用于选择目标形状的输出填充量: 普通卷积取整后, 同一个 n' 可能对应 s 种原输入长度。选择其中一种长度才能确定被转置的完整矩阵。 o 是尺寸约定, 不表示把 o 个零作为最终输出值附在末尾。二维情况分别对高、宽应用该式; 若使用不对称填充或额外裁剪, 应按对应线性映射重

新核对。跨步转置卷积可理解为先在输入位置之间插零，再进行适当的滤波与裁剪；不同位置的覆盖次数可能不均匀，需要检查输出中的周期性纹理。卷积尺寸与转置关系的系统说明见 Dumoulin 和 Visin 的算术指南⁶。

⁶ V. Dumoulin, F. Visin, *A Guide to Convolution Arithmetic for Deep Learning* In arXiv preprint arXiv:1603.07285, 2016

9.2.3 卷积的实现

实现一个卷积映射，既要选择求得输出的计算算法，也要安排数据的存储与读取。下面先按如何计算局部乘积及其和展开六条算法路线：直接逐项计算，改写为矩阵乘法，或利用多项式、滤波变换、傅里叶变换及核的低秩结构。矩阵路线中的 Strassen 属于矩阵乘法的内部算法。节末再简要讨论展开、取数、分块与融合等工程选择，说明同一算法怎样组织实际计算。

此前的单矩阵例子只保留一个数值平面，现在将第 9.1 节的多通道组织写成张量。一个通道在全部空间位置上的响应构成一张**特征图** (feature map)。单个输入的形狀为 $\mathbf{X} \in \mathbb{R}^{h \times w \times c_{in}}$ ，普通密集卷积的核张量为 $\mathbf{W} \in \mathbb{R}^{k_h \times k_w \times c_{in} \times c_{out}}$ 。固定一个输出通道，其核覆盖全部输入通道：对空间窗口和输入通道共同求和，产生一个输出值；换用另一组核权重便产生另一个输出通道。因此输入通道轴参与求和，输出通道轴保留在结果中，图 9.13 给出了对应示意。

以下比较同一个互相关映射，忽略激活；偏置可在累积完成后加入。设小批量含 n_b 个输入，输入、输出通道数为 c_{in}, c_{out} ，输出空间尺寸为 $h' \times w'$ 。记

$$q = k_h k_w c_{in}, \quad m = n_b h' w',$$

即一个窗口的元素数与全部输出位置数。普通密集卷积需要 $c_{out} q m$ 次乘加；比较额外存储时，输入、核和最终输出不计入工作区。这里把输入数值与核权重相乘称为核心乘法，另行计算固定变换中的加减与常数乘法。减少核心乘法并不自动减少总耗时，后文会同时交代新增的计算与存储。

这些算法有两种不同的出发点。矩阵化汇集原有点积，随后可以改变矩阵乘法的内部算法；变换类算法则先对输入与核作线性组合，用较少的组合乘法恢复输出。后一条路线之所以可行，是因为一个乘积可以同时包含多个原始乘积，后续加减又能消去不需要的项。空间可分离路线还要利用核自身的低秩结构。

9.2.3.1 直接计算：逐项求和

直接算法在每个输出位置逐项累积窗口中的贡献。将批量索引记为 t ，输入元素为 $x_{t,i,j,c}$ ， $w_{a,b,c,o}$ 表示核位置 (a, b) 上从输入通道 c 到输出通道 o 的权重。记 $u(i, a) = i s_h - p_t + a d_h$ 、 $v(j, b) = j s_w - p_l + b d_w$ ，即式(9.12)中的实际读取位置，零填充下的核心步骤如下。

算法 9.1 直接多通道互相关**输入：** 输入 $\mathbf{X}$ 、核 $\mathbf{W}$ 、偏置 $\mathbf{b}$ 及形状、采样设置**输出：** 输出预激活 $\mathbf{Z}$

```

1: for 每个合法的  $(t, i, j, o)$  do
2:    $z_{t,i,j,o} \leftarrow b_o$ 
3:   for 每个核位置  $(a, b)$  和输入通道  $c$  do
4:     读取扩展输入  $\tilde{x}_{t,u(i,a),v(j,b),c}$ 
5:      $z_{t,i,j,o} \leftarrow z_{t,i,j,o} + w_{a,b,c,o} \tilde{x}_{t,u(i,a),v(j,b),c}$ 
6:   end for
7: end for

```

算法9.1的一次外层迭代只负责一个输出。核位置确定空间偏移，输入通道决定读取哪个数值，输出通道决定使用哪组权重；所有贡献加到同一个累积器中，完成后才写出。相邻输出重新使用核，另一个输出通道则使用另一个核，但二者都从同一输入张量取数。

对式(9.9)的左上输出，顺序计算的四项是 1×1 、 2×0 、 5×0 和 $6 \times (-1)$ ，总和为 -5 。零权重是这个例子的特殊取值，普通密集算法仍按四个位置组织计算；只有专门利用零权重结构，才能省去相应乘法。每个窗口含 q 项，一共有 $c_{\text{out}}m$ 个输出，因此乘加量为

$$O(n_b h' w' c_{\text{in}} c_{\text{out}} k_h k_w)。(9.16)$$

直接算法逐项保留局部求和结构，额外工作区可以只包含若干累积器，但算术量随核面积、通道数与输出位置数相乘。相邻窗口包含重复输入，并不意味着必须重复从主内存读取；这种复用属于第 9.2.3.7 节的数据调度问题。判断一种计算算法时，应先固定数学运算及其乘加量，再考察它在具体存储层次中的执行方式。

9.2.3.2 矩阵化计算与 Strassen 递归乘法

直接算法中的局部点积彼此具有相同长度，可以集中交给**通用矩阵乘法** (general matrix multiplication, GEMM) 计算。从代数上把每个输入窗口展平成一行，得到 $\mathbf{P} \in \mathbb{R}^{q \times m}$ ；每个输出核展平成一行，得到 $\mathbf{W}_{\text{loc}} \in \mathbb{R}^{c_{\text{out}} \times q}$ 。所有输出写为

$$\mathbf{Z}_{\text{col}} = \mathbf{W}_{\text{loc}} \mathbf{P} + \mathbf{b} \mathbf{1}_m^T。(9.17)$$

其中 $\mathbf{1}_m$ 为 m 维全一向量，计算后将列索引还原为批量和空间索引即可。矩阵的每一列对应一个空间窗口，每一行输出对应一个核；乘积中的第 (o, ℓ) 个元素正是第 o 个核与第 ℓ 个窗口的点积。多输入通道并不改变这个关系，只是让每个窗口列更长；多输出通道则让核矩阵增加行数。展开的元素顺序必须与核的展平顺序一致；例如先遍历核行、核列，再遍历通道，就不能把核按通道优先展平。

对式(9.9)，按行优先排列窗口与窗口中的元素，有

$$\mathbf{P} = \begin{bmatrix} 1 & 2 & 3 & 5 & 6 & 7 & 9 & 10 & 11 \\ 2 & 3 & 4 & 6 & 7 & 8 & 10 & 11 & 12 \\ 5 & 6 & 7 & 9 & 10 & 11 & 13 & 14 & 15 \\ 6 & 7 & 8 & 10 & 11 & 12 & 14 & 15 & 16 \end{bmatrix}, \quad (9.18)$$

核行为 $(1, 0, 0, -1)$ ，矩阵乘积得到九个 -5 。例如前两列分别是 $(1, 2, 5, 6)^\top$ 和 $(2, 3, 6, 7)^\top$ ，同一核行与它们相乘，得到 $1-6$ 与 $2-7$ ，图 9.8 给出了对应关系。这种矩阵表示没有减少普通算法的 $c_{\text{out}}qm$ 次乘加，却把全部局部点积集中成同一个矩阵乘法。 $\mathbf{P}$ 可以是一个用于推导的逻辑矩阵，是否真的复制每个元素，留到第 9.2.3.7 节讨论。




图 9.8 局部点积如何成为矩阵乘法。图中只取两个相邻窗口，按核行、核列的顺序展平成 $\mathbf{P}$ 的两列；核按相同顺序展平成一行。矩阵乘法同时得到这两个窗口的输出，完整计算包含九列。这里画的是代数上的窗口矩阵，是否实际复制全部数值由工程实现决定。

矩阵化之后还可以选择不同的矩阵乘法算法。下面的 Strassen 改变块乘法数量，它从属于矩阵乘法这条计算路线，与是否显式保存窗口是两个问题。

Strassen 递归乘法 设 $\mathbf{C} = \mathbf{AB}$ ，将两个输入矩阵和结果矩阵各按 2×2 等形状划分，普通算法给出

$$\begin{aligned} \mathbf{C}_{1,1} &= \mathbf{A}_{1,1}\mathbf{B}_{1,1} + \mathbf{A}_{1,2}\mathbf{B}_{2,1}, \\ \mathbf{C}_{1,2} &= \mathbf{A}_{1,1}\mathbf{B}_{1,2} + \mathbf{A}_{1,2}\mathbf{B}_{2,2}, \\ \mathbf{C}_{2,1} &= \mathbf{A}_{2,1}\mathbf{B}_{1,1} + \mathbf{A}_{2,2}\mathbf{B}_{2,1}, \\ \mathbf{C}_{2,2} &= \mathbf{A}_{2,1}\mathbf{B}_{1,2} + \mathbf{A}_{2,2}\mathbf{B}_{2,2}. \end{aligned} \quad (9.19)$$

四个输出各含两次块乘法，共需八次。Strassen 算法用七个组合块乘积替代这八次乘法，定义

$$\begin{aligned}
 \mathbf{M}_1 &= (\mathbf{A}_{1,1} + \mathbf{A}_{2,2})(\mathbf{B}_{1,1} + \mathbf{B}_{2,2}), \\
 \mathbf{M}_2 &= (\mathbf{A}_{2,1} + \mathbf{A}_{2,2})\mathbf{B}_{1,1}, \\
 \mathbf{M}_3 &= \mathbf{A}_{1,1}(\mathbf{B}_{1,2} - \mathbf{B}_{2,2}), \\
 \mathbf{M}_4 &= \mathbf{A}_{2,2}(\mathbf{B}_{2,1} - \mathbf{B}_{1,1}), \\
 \mathbf{M}_5 &= (\mathbf{A}_{1,1} + \mathbf{A}_{1,2})\mathbf{B}_{2,2}, \\
 \mathbf{M}_6 &= (\mathbf{A}_{2,1} - \mathbf{A}_{1,1})(\mathbf{B}_{1,1} + \mathbf{B}_{1,2}), \\
 \mathbf{M}_7 &= (\mathbf{A}_{1,2} - \mathbf{A}_{2,2})(\mathbf{B}_{2,1} + \mathbf{B}_{2,2}).
 \end{aligned} \tag{9.20}$$

由这些结果恢复输出：

$$\begin{aligned}
 \mathbf{C}_{1,1} &= \mathbf{M}_1 + \mathbf{M}_4 - \mathbf{M}_5 + \mathbf{M}_7, \\
 \mathbf{C}_{1,2} &= \mathbf{M}_3 + \mathbf{M}_5, \quad \mathbf{C}_{2,1} = \mathbf{M}_2 + \mathbf{M}_4, \\
 \mathbf{C}_{2,2} &= \mathbf{M}_1 - \mathbf{M}_2 + \mathbf{M}_3 + \mathbf{M}_6.
 \end{aligned} \tag{9.21}$$

这种组合靠的是多余项的抵消，而不是省略某个输入块。以左上输出为例，把四个中间量按左因子归并，有

$$\begin{aligned}
 \mathbf{M}_1 + \mathbf{M}_4 - \mathbf{M}_5 + \mathbf{M}_7 &= \mathbf{A}_{1,1}(\mathbf{B}_{1,1} + \mathbf{B}_{2,2} - \mathbf{B}_{2,2}) \\
 &\quad + \mathbf{A}_{1,2}(-\mathbf{B}_{2,2} + \mathbf{B}_{2,1} + \mathbf{B}_{2,2}) \\
 &\quad + \mathbf{A}_{2,2}(\mathbf{B}_{1,1} + \mathbf{B}_{2,2} + \mathbf{B}_{2,1} - \mathbf{B}_{1,1} - \mathbf{B}_{2,1} - \mathbf{B}_{2,2}) \\
 &= \mathbf{A}_{1,1}\mathbf{B}_{1,1} + \mathbf{A}_{1,2}\mathbf{B}_{2,1}.
 \end{aligned} \tag{9.22}$$

展开过程没有交换左右因子，因而对矩阵块同样成立。其余三个输出也可按式(9.21)验证。核查例子取

$$\mathbf{A} = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix}, \quad \mathbf{B} = \begin{bmatrix} 5 & 6 \\ 7 & 8 \end{bmatrix}.$$

七个中间乘积依次为 65, 35, -2, 8, 24, 22, -30，恢复后的结果是 $\begin{bmatrix} 19 & 22 \\ 43 & 50 \end{bmatrix}$ ，与普通乘法一致。

这一层递归将八次块乘法降为七次，块加减却从四次增为十八次，其中十次用于形成乘法输入，八次用于恢复输出。对 $n \times n$ 方阵递归时，每个子问题的边长减半，加减的工作量仍与本层全部元素数成正比，因此 $T(n) = 7T(n/2) + O(n^2)$ ，得到 $O(n^{\log_2 7})$ 。指数降低来自每层少一个乘法子问题，额外加减则是所支付的代价⁷。

实现时通常只递归到合适阈值，底层仍调用高效 GEMM；奇数尺寸需要拆分尾部或补齐，临时块应复用，某些加减可并入数据打包。卷积可在

⁷ V. Strassen, *Gaussian Elimination Is Not Optimal* In *Numerische Mathematik*, 1969, vol. 13, no. 4, pp. 354–356

式(9.17)的矩阵乘法阶段接入该算法, 但 $c_{\text{out}} \times q$ 与 $q \times m$ 常高度不对称, 盲目补成方阵会浪费大量工作。递归、额外加减与写回可能抵消节省; 相减还会改变舍入误差的传播。Strassen 是可用的矩阵算法路线, 不能由渐近指数直接推出它适合每个卷积层。

9.2.3.3 Toom-Cook: 求值、乘法与插值

有限序列还可写成多项式 $X(z) = \sum_i x_i z^i$ 、 $K(z) = \sum_a k_a z^a$ 。因为 $z^i z^a = z^{i+a}$, 乘积中 z^j 的系数正是

$$c_j = \sum_{i+a=j} x_i k_a,$$

即完整数学卷积的第 j 个输出。若输入与核分别长 n_x, n_k , 乘积次数至多为 $n_x + n_k - 2$, 需要恢复 $n_x + n_k - 1$ 个系数。直接算法逐一形成 $n_x n_k$ 个乘积; 另一种办法是先知道乘积多项式在足够多的点上取什么值, 再解出系数。Toom-Cook 方法将多项式分块, 在选定点求值, 逐点相乘, 再插值恢复乘积; 图 9.10 给出这条计算路径。

次数不超过 $L-1$ 的多项式由 L 个不同有限点的值唯一确定: 两组候选系数的差若在这 L 个点都为零, 就会使次数不超过 $L-1$ 的非零多项式有 L 个根, 这不可能。求值等于将系数转换为这些点值, 插值则从点值恢复系数。选点固定后, 两个转换都是固定的线性运算; 原来许多系数间的乘法, 被集中到点值的逐项乘法中。

两个一次多项式只需在 $0, 1, \infty$ 三个点相乘, 其中 ∞ 表示取最高次项系数。令 $m_0 = x_0 k_0$ 、 $m_\infty = x_1 k_1$ 、 $m_1 = (x_0 + x_1)(k_0 + k_1)$, 则

$$(x_0 + x_1 z)(k_0 + k_1 z) = m_0 + (m_1 - m_0 - m_\infty)z + m_\infty z^2. \quad (9.23)$$

中间系数本来是 $x_0 k_1 + x_1 k_0$, 现在通过一次组合乘法减去两端乘积得到。四次数据与核之间的乘法降为三次; 这一最小例子也称 Karatsuba 乘法。例如 $\mathbf{x} = (1, 2)$ 、 $\mathbf{k} = (1, -1)$ 时, 三个乘积为 $1, 0, -2$, 恢复得到系数 $(1, 1, -2)$ 。

为了连接下一节的小块滤波, 考虑长度三与长度二的完整卷积。此时 $X(z) = x_0 + x_1 z + x_2 z^2$ 、 $K(z) = k_0 + k_1 z$, 乘积 $S(z) = \sum_{j=0}^3 c_j z^j$ 需要四项系数。取 $0, 1, -1, \infty$, 形成

$$\begin{aligned} r_0 &= x_0 k_0, & r_\infty &= x_2 k_1, \\ r_+ &= (x_0 + x_1 + x_2)(k_0 + k_1), \\ r_- &= (x_0 - x_1 + x_2)(k_0 - k_1). \end{aligned} \quad (9.24)$$

这里 $S(1) = c_0 + c_1 + c_2 + c_3$, $S(-1) = c_0 - c_1 + c_2 - c_3$, $S(0) = c_0$, 最高次项系数为 c_3 。将正、负一点的值相加或相减, 便分别分离偶数次与奇数次

系数, 得到

$$\begin{aligned} c_0 &= r_0, & c_1 &= (r_+ - r_-)/2 - r_\infty, \\ c_2 &= (r_+ + r_-)/2 - r_0, & c_3 &= r_\infty. \end{aligned} \quad (9.25)$$

对 $\mathbf{x} = (1, 2, 3)$ 、 $\mathbf{k} = (1, -1)$, 四个乘积为 $r_0 = 1, r_+ = 0, r_- = 4, r_\infty = -3$, 恢复出 $(1, 1, 1, -3)$ 。六次核心乘法降为四次, 但求值与恢复中的加减、除以二仍需执行。 ∞ 只是取最高次项的记号, 不能把无穷大的浮点数传入计算。

三段分块与递归 三段分块进一步展示插值过程。对两个二次多项式, 在 $0, 1, -1, 2, \infty$ 求值并相乘, 记结果为 $r_0, r_1, r_{-1}, r_2, r_\infty$ 。乘积次数至多为四, 正好需要五个条件: c_0, c_4 由两端直接给出; $r_1 + r_{-1}$ 分离偶数次项, $r_1 - r_{-1}$ 给出 $c_1 + c_3$; 再用 r_2 区分这两个奇数次系数。乘积系数 $c_0, \dots, c_4$ 可按式恢复:

$$\begin{aligned} c_0 &= r_0, & c_4 &= r_\infty, \\ c_2 &= (r_1 + r_{-1})/2 - c_0 - c_4, \\ v &= (r_1 - r_{-1})/2, \\ u &= (r_2 - c_0 - 4c_2 - 16c_4)/2, \\ c_3 &= (u - v)/3, & c_1 &= v - c_3. \end{aligned} \quad (9.26)$$

这里 u, v 只是插值中间量。五次求值后的乘法替代九次原始系数乘法, 但新增了求值加减、常数乘除和插值。例如 $\mathbf{x} = (1, 2, 3)$ 、 $\mathbf{k} = (1, -1, 2)$ 的五个点值乘积是 $1, 12, 8, 119, 6$; 式(9.26)先给出 $c_2 = 3, v = 2, u = 5$, 再得到 $c_3 = 1, c_1 = 1$, 完整输出为 $(1, 1, 3, 1, 6)$ 。

长序列可以每 ℓ 项分为一段, 写成 $X(z) = X_0(z) + z^\ell X_1(z) + z^{2\ell} X_2(z)$, 核也同样分段。把 z^ℓ 暂看成外层变量, 刚才的五次乘法就变为五个短多项式乘法; 每个段内乘积再递归计算。插值后将第 j 个段内结果平移 $j\ell$ 位, 并把重叠系数相加。对两条长度相近的序列, 三等分递归满足 $T(n) = 5T(n/3) + O(n)$, 理想成本为 $O(n^{\log_3 5})$; 它不能直接作为长输入与短 CNN 核的复杂度, 因为两者形状并不相近。

实现需选择分块长度和求值点, 保存或流式产生求值结果, 并把恢复的系数按原位累加。求值点过大或插值中出现相近量相减, 可能放大浮点误差; 低精度下尤其要检查变换后的动态范围。数学卷积与网络互相关可通过翻转核及裁剪建立对应, 但网络通常只需一小段输出, 计算完整多项式乘积可能浪费工作。Toom-Cook 解释了“用变换交换乘法与加法”的一般思路, 接下来的 Winograd 则直接面向小块滤波输出。

9.2.3.4 Winograd 最小滤波：直接恢复小块输出

Toom-Cook 说明了怎样通过点值恢复完整卷积，但 CNN 只需要每个小块中的若干合法输出。Winograd 最小滤波沿用“变换、相乘、恢复”的结构，将恢复目标改为这些输出。要理解固定变换矩阵从何而来，可以先从多项式余数出发，再把完整卷积算法转置为滤波算法。

多项式余数怎样保留乘积信息 多项式除以 $z - t$ 的余数是常数 $S(t)$ ；因此在此 t 处求值，也可以理解为保留关于 $z - t$ 的余数。**多项式中国剩余定理** 说明：若若干基多项式两两互素，则关于它们的各个余数共同确定一个关于其乘积的余数。这里的“互素”表示没有共同的非恒定因子；重构结果的次数小于基多项式乘积的次数。这个次数条件保证唯一性，不能只给若干余数而忽略剩余的高次项。

沿用式(9.24)，选取 $z, z - 1, z + 1$ ，其乘积为 $M(z) = z^3 - z$ 。由于 S 次数至多为三、最高次项系数是 r_∞ ，可写成

$$S(z) = r_\infty M(z) + R(z), \quad \deg R < 3. \quad (9.27)$$

在 $0, 1, -1$ 处， M 都为零，故 R 保留 S 在这三点的值 r_0, r_+, r_- 。下面三个二次多项式各自在一个点等于一、在另外两点等于零：

$$L_0(z) = 1 - z^2, \quad L_+(z) = (z^2 + z)/2, \quad L_-(z) = (z^2 - z)/2。$$

因而余数的具体重构式是

$$R(z) = r_0 L_0(z) + r_+ L_+(z) + r_- L_-(z)。 \quad (9.28)$$

代入并展开 $r_\infty(z^3 - z) + R(z)$ ，就得到式(9.25)的四项系数。该例中一次基多项式的余数就是点值，所以余数重构与 Toom-Cook 插值给出同一个计算过程；选择更一般的基多项式时，余数也可能是低次多项式，而非一个数值。

从完整卷积转为小块滤波 固定长度三的核 $\mathbf{g} = (g_0, g_1, g_2)^\top$ ，将它与长度二的向量 $\mathbf{b}$ 作完整数学卷积，可写为 $\mathbf{s} = \mathbf{H}_g \mathbf{b}$ ，其中

$$\mathbf{H}_g = \begin{bmatrix} g_0 & 0 \\ g_1 & g_0 \\ g_2 & g_1 \\ 0 & g_2 \end{bmatrix}, \quad \mathbf{H}_g^\top \mathbf{d} = \begin{bmatrix} d_0 g_0 + d_1 g_1 + d_2 g_2 \\ d_1 g_0 + d_2 g_1 + d_3 g_2 \end{bmatrix}。 \quad (9.29)$$

右侧正是长度四输入 $\mathbf{d}$ 经过长度三核产生的两个互相关输出。把前面完整卷积的线性计算图转置，就可将“两个输入、四个完整输出”变为“四个

输入、两个合法输出”，核心乘法仍为四次。

更具体地，若完整卷积算法写为 $\mathbf{s} = \mathbf{R}[(\mathbf{E}\mathbf{g}) \odot (\mathbf{Q}\mathbf{b})]$ ，其中 $\mathbf{E}, \mathbf{Q}$ 负责求值、 $\mathbf{R}$ 负责恢复，则固定核后，整个映射是 $\mathbf{R}\text{Diag}(\mathbf{E}\mathbf{g})\mathbf{Q}$ 。转置后得到

$$\mathbf{H}_g^\top \mathbf{d} = \mathbf{Q}^\top [(\mathbf{E}\mathbf{g}) \odot (\mathbf{R}^\top \mathbf{d})].$$

这里 Diag 把向量放到对角线上；转置只反转线性变换的顺序，逐项乘法仍使用相同的四个核组合。将固定系数 $1/2$ 在数据变换与核变换之间重新分配，就得到下面常用的公式。这也解释了它与前节转置卷积的联系：利用的是线性映射的转置，而不是求逆。

记 $F(m, r)$ 为用 r 个核系数计算 m 个相邻互相关输出，这里的 m 指一个小块的输出数。 $F(2, 3)$ 读取 d_0, d_1, d_2, d_3 ，核为 g_0, g_1, g_2 ，目标是

$$y_0 = d_0 g_0 + d_1 g_1 + d_2 g_2, \quad y_1 = d_1 g_0 + d_2 g_1 + d_3 g_2.$$

直接计算需要六次数据与核的乘法。通过固定变换，计算

$$\begin{aligned} m_1 &= (d_0 - d_2)g_0, \\ m_2 &= (d_1 + d_2)(g_0 + g_1 + g_2)/2, \\ m_3 &= (d_2 - d_1)(g_0 - g_1 + g_2)/2, \\ m_4 &= (d_1 - d_3)g_2, \\ y_0 &= m_1 + m_2 + m_3, \quad y_1 = m_2 - m_3 - m_4, \end{aligned} \quad (9.30)$$

就能用四次核心乘法恢复同样的两个输出。恢复式可以逐项验证：

$$\begin{aligned} m_2 + m_3 &= d_1 g_1 + d_2 (g_0 + g_2), \\ m_2 - m_3 &= d_1 (g_0 + g_2) + d_2 g_1. \end{aligned} \quad (9.31)$$

第一式加上 $m_1 = (d_0 - d_2)g_0$ ，消去 $d_2 g_0$ ，便恢复 y_0 ；第二式减去 $m_4 = (d_1 - d_3)g_2$ ，消去 $d_1 g_2$ ，便恢复 y_1 。每个组合乘积同时承担多个原始项，输出恢复负责消去多余项。

把这组标量计算写成矩阵形式，便能区分输入变换、核变换和输出恢复。适用于这里互相关方向的矩阵为

$$\mathbf{B}^\top = \begin{bmatrix} 1 & 0 & -1 & 0 \\ 0 & 1 & 1 & 0 \\ 0 & -1 & 1 & 0 \\ 0 & 1 & 0 & -1 \end{bmatrix}, \quad \mathbf{G} = \begin{bmatrix} 1 & 0 & 0 \\ 1/2 & 1/2 & 1/2 \\ 1/2 & -1/2 & 1/2 \\ 0 & 0 & 1 \end{bmatrix}, \quad (9.32)$$

$$\mathbf{A}^\top = \begin{bmatrix} 1 & 1 & 1 & 0 \\ 0 & 1 & -1 & -1 \end{bmatrix}. \quad (9.33)$$

它们的尺寸分别为 4×4 、 4×3 和 2×4 。令 $\mathbf{d} = (d_0, d_1, d_2, d_3)^\top$ 、 $\mathbf{g} = (g_0, g_1, g_2)^\top$ ，则式(9.30)等价于

$$\mathbf{m} = (\mathbf{B}^\top \mathbf{d}) \odot (\mathbf{G} \mathbf{g}), \quad \mathbf{y} = \mathbf{A}^\top \mathbf{m}, \quad (9.34)$$

其中 $\mathbf{m} = (m_1, m_2, m_3, m_4)^\top$ ， $\mathbf{y} = (y_0, y_1)^\top$ 。

图 9.9 取 $\mathbf{d} = (1, 2, 3, 4)$ 、 $\mathbf{g} = (1, 2, 3)$ ，得到 $\mathbf{m} = (-2, 15, 1, -6)$ ，再恢复 $(14, 20)$ ；直接计算也给出 $1 + 4 + 9 = 14$ 和 $2 + 6 + 12 = 20$ 。输入变换需要四次加减，核变换可用三次加减与两次乘以 $1/2$ ，输出恢复需要四次加减。含 $1/2$ 的核变换可在核参数不变时复用，不应把全部变换开销计为零。




图 9.9 一维 $F(2, 3)$ 的完整数值路径。输入 $\mathbf{d} = (1, 2, 3, 4)^\top$ 与核 $\mathbf{g} = (1, 2, 3)^\top$ 分别变为四个组合值，按位置相乘得到 $\mathbf{m} = (-2, 15, 1, -6)^\top$ ，再用输出变换恢复两个互相关结果。四次核心乘法替代直接算法的六次乘法，加减与固定系数变换仍有成本。

沿两个轴组合变换 复用上述三个矩阵，把一维变换沿两个轴组合， 3×3 核 $\mathbf{K}$ 与 4×4 输入块 $\mathbf{D}$ 产生 2×2 输出：

$$\begin{aligned} \mathbf{U} &= \mathbf{G} \mathbf{K} \mathbf{G}^\top, & \mathbf{V} &= \mathbf{B}^\top \mathbf{D} \mathbf{B}, \\ \mathbf{Y} &= \mathbf{A}^\top (\mathbf{U} \odot \mathbf{V}) \mathbf{A}. \end{aligned} \quad (9.35)$$

左乘处理行方向，右乘处理列方向；因此 $\mathbf{U}, \mathbf{V}$ 均为 4×4 ，逐元素乘积有十六项，输出恢复将其变为 2×2 。这不是对每个输出独立使用一维技巧，而是两轴都先形成组合，再让十六个乘积服务于全部四个输出。直接计算的 $4 \times 9 = 36$ 次核心乘法降为 16 次⁸。多通道时，每个输入通道分别变换，在变换域按通道累积 $\sum_c \mathbf{U}_{c,o} \odot \mathbf{V}_c$ ，然后对每个输出通道恢复空间块。输入变换可供多个输出通道复用，核变换可供多个空间块与批量样本复用。由于输出变换是线性的，先对通道求和再恢复，与逐通道恢复后相加完全等价，却只需为每个输出通道执行一次恢复。若同时处理许多输入块，在每个变换位置 (ξ, ν) 上，还可把全部核组合排成 $c_{\text{out}} \times c_{\text{in}}$ 矩阵、输入组合排成 $c_{\text{in}} \times n_{\text{tile}}$ 矩阵，进行一次通道矩阵乘法； n_{tile} 是当前输入块数。 $F(2 \times 2, 3 \times 3)$ 因而可以组织为十六组通道矩阵乘法。这种结构使变换算法也能使用 GEMM，与前面的矩阵化路线并不矛盾。

⁸ A. Lavin, S. Gray, *Fast Algorithms for Convolutional Neural Networks* In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2016, pp. 4013–4021




图 9.10 变换类卷积的共同流程与不同目标。Toom-Cook 通过多项式求值及插值恢复完整乘积系数；Winograd 通过固定小矩阵恢复所需输出块；FFT 在补零后的频域相乘并反变换。输入和核可以分别变换，变换结果按输入通道相乘并求和；能复用多少次，决定变换开销能否被摊薄。

实现时先为每个输入、输出通道对变换核，再将输出切成互不重叠的 2×2 块。每个输出块读取一个 4×4 输入块，变换输入、完成通道乘加、恢复四个空间输出，再加偏置。相邻输出块的起点相隔两格，对应输入块重叠两行或两列；边缘不足一块时需填充或单独处理。变换后的核有 16 个系数而非 9 个，活动值工作区也会扩大；可以分块处理以控制内存。更大输出块虽然进一步减少单位输出的核心乘法，却通常增加变换成本和数值敏感性。上述方案直接适用于步长一、无空洞的 3×3 设置，其他设置需要另行构造算法或选择别的内核。

9.2.3.5 FFT 与分块频域卷积

若求值和插值自身仍有很高的成本，减少点值乘法就未必能带来收益。**快速傅里叶变换** (fast Fourier transform, FFT) 利用单位根的对称性，加速从系数到点值、再从点值到系数的转换。Toom-Cook 在少数实数点上求值，FFT 则选取复平面上等间隔的单位根。若补零后的序列长 N ，记 $\zeta_N = \exp(-2\pi i/N)$ ，其中 i 为虚数单位。长度 N 的离散傅里叶变换 (discrete Fourier transform, DFT) 及其逆变换为

$$\begin{aligned} \hat{x}_\omega &= \sum_{i=0}^{N-1} x_i \zeta_N^{\omega i}, & \omega &= 0, \dots, N-1, \\ x_i &= \frac{1}{N} \sum_{\omega=0}^{N-1} \hat{x}_\omega \zeta_N^{-\omega i}, & i &= 0, \dots, N-1. \end{aligned} \quad (9.36)$$

正变换就是在 ζ_N^ω 处计算 $X(z)$ 的值，逆变换恢复系数。归一化因子 $1/N$ 不可省略；因为单位根的正交关系使 $\sum_{\omega} \zeta_N^{\omega(i-j)}$ 在 $i=j$ 时等于 N ，在不同索引时等于零。与一般点值插值相比，单位根的规则结构允许快速求值和快速恢复。

FFT 怎样加速求值与恢复 直接 DFT 为 N 个频率各求一个长度 N 的和，需要 $O(N^2)$ 工作。以 N 为二的幂为例，把系数分成偶数索引与奇数索引，

分别得到长度 $N/2$ 的序列, 其 DFT 记为 E_ω, O_ω 。由于 $\zeta_N^2 = \zeta_{N/2}$, 对 $0 \leq \omega < N/2$ 有

$$\begin{aligned}\hat{x}_\omega &= E_\omega + \zeta_N^\omega O_\omega, \\ \hat{x}_{\omega+N/2} &= E_\omega - \zeta_N^\omega O_\omega.\end{aligned}\quad (9.37)$$

同一对 E_ω, O_ω 同时服务两个频率, 第二式的减号来自 $\zeta_N^{N/2} = -1$ 。这一步没有丢掉一半频率, 而是用两个较小 DFT 和线性合并恢复全部频率。递归满足 $T(N) = 2T(N/2) + O(N)$, 共有 $\log_2 N$ 层、每层 $O(N)$ 工作; 逆变换改变指数符号并除以 N , 可沿用同样的递归。这是 Cooley-Tukey 分治的一种基二形式, 其他合成长度也可按其因子分解, 不要求所有 FFT 的长度都为二的幂⁹。

⁹ J. W. Cooley, J. W. Tukey, *An Algorithm for the Machine Calculation of Complex Fourier Series* In *Mathematics of Computation*, 1965, vol. 19, no. 90, pp. 297–301

频域乘法为什么等于卷积 对循环卷积 $y_j = \sum_{i=0}^{N-1} x_i k_{(j-i) \bmod N}$, 将 DFT 中的求和按 $j = i + a \pmod{N}$ 重排, 得到

$$\hat{y}_\omega = \sum_{i=0}^{N-1} \sum_{a=0}^{N-1} x_i k_a \zeta_N^{\omega(i+a)} = \hat{x}_\omega \hat{k}_\omega. \quad (9.38)$$

周期性保证索引回绕不会改变单位根的幂。空间中的加权求和变成每个频率上的一次乘法, 求值后只需 N 项乘法, 再用 $O(N \log N)$ 成本逆变换回去。这一卷积定理可写为

$$\mathbf{x} *_N \mathbf{k} = \mathcal{F}_N^{-1}(\mathcal{F}_N(\mathbf{x}) \odot \mathcal{F}_N(\mathbf{k})). \quad (9.39)$$

这直接得到循环卷积。若要计算长度 n_x, n_k 的有限序列的线性卷积, 应先将两者补零到 $N \geq n_x + n_k - 1$, 避免末端贡献回绕叠加到开头。二维情况沿高、宽分别满足补零要求。

例如 $(1, 2, 3, 4)$ 与 $(1, -1)$ 的完整数学卷积是 $(1, 1, 1, 1, -4)$, 至少需要长度五的变换。若只取长度四, 最后一项回绕, 首项变为 $1 - 4 = -3$, 得到 $(-3, 1, 1, 1)$, 已是另一个运算。网络中的 valid 互相关应先按约定翻转核, 再选取完整线性卷积中对应的输出位置。例如先把 $(1, -1)$ 翻成 $(-1, 1)$, 完整卷积为 $(-1, -1, -1, -1, 4)$, 保留索引一至三便得到互相关输出 $(-1, -1, -1)$ 。补零、翻转和裁剪不能只靠“FFT 后乘一下”省略。

多通道二维卷积先分别变换输入和核, 在每个频率上计算 $\hat{y}_o = \sum_c \hat{x}_c \hat{k}_{c,o}$, 再对每个输出通道反变换。若补零后的网格含 N 个位置, 核心频域乘加量为 $O(n_b c_{in} c_{out} N)$, 另有输入、核及输出的变换成本, 其量级分别为

$$O(n_b c_{in} N \log N), \quad O(c_{in} c_{out} N \log N), \quad O(n_b c_{out} N \log N).$$

这里 N 是补零后二维网格的总位置数, 频域乘法通常是复数乘法, 不能直

接与一次实数乘法等价计价。输入频谱可供多个输出核复用，核频谱在参数不变时可跨样本复用；训练中参数更新后需要重算。Mathieu 等研究了在 CNN 中利用这些复用关系的 FFT 实现¹⁰。

长输入怎样逐块计算 FFT 算法也可以逐块计算，以限制变换规模。**重叠相加** (overlap-add) 将输入分块，每块补零后计算完整线性卷积，再将重叠的输出贡献相加；**重叠保留** (overlap-save) 则让相邻输入块保留核长减一的重叠，只输出每块中没有循环污染的部分。一维核长 k 、变换长度 N 时，每块可保留 $N - k + 1$ 个新输出。例如将 $(1, 2, 3, 4)$ 拆为 $(1, 2)$ 与 $(3, 4)$ ，分别和 $(1, -1)$ 作完整卷积，得到 $(1, 1, -2)$ 与 $(3, 1, -4)$ 。第二块原本从位置二开始，恢复后也要平移两位；重叠位置的 -2 与 3 相加，便得到整段输出 $(1, 1, 1, 1, -4)$ ，见图 9.11。每块内部仍须补零至至少 $2 + 2 - 1 = 3$ ，分块不能消除线性卷积的补零要求。

重叠保留选择另一种组织方式。取核长二、 $N = 4$ ，每个输入块保留前一块最后一个输入值，再接三个新值。首块为 $(0, 1, 2, 3)$ ，其循环卷积为 $(-3, 1, 1, 1)$ ；丢掉受回绕污染的第一项，保留 $(1, 1, 1)$ 。下一块为 $(3, 4, 0, 0)$ ，保留结果 $(1, -4, 0)$ ，按目标长度截取前两项，仍恢复同一个完整输出。重叠相加在输出端相加，重叠保留在输入端重叠并丢弃污染位置，两者不能混用拼接规则。




图 9.11 重叠相加的数值例子。输入在原位置零和二分别开始两个长度二的块，块内补零后计算与 $(1, -1)$ 的完整卷积，恢复到图上的五个全局输出位置。红色区域表示该块可能产生贡献的位置，区域外记为零。虚线框内的两项贡献相加为一，最终结果与不分块的线性卷积相同。

块太小使变换和重叠开销增加，块太大增加内存及延迟。复数数组、变换代价与跨步后被丢弃的输出，都会影响 FFT 是否适合某一层。

9.2.3.6 空间可分离核：利用低秩结构

还有一种加速依赖核自身的代数结构。若单通道核可写成 $k_{a,b} = u_a v_b$ ，即 $\mathbf{K} = \mathbf{u}\mathbf{v}^\top$ ，二维滤波就可分解为一个方向的长度 k_h 滤波和另一个方向的

¹⁰ M. Mathieu, M. Henaff, Y. Le-Cun, *Fast Training of Convolutional Networks through FFTs* In International Conference on Learning Representations, 2014

长度 k_w 滤波。这一分解直接来自求和顺序：

$$\begin{aligned} t_{i,j} &= \sum_{b=0}^{k_w-1} v_b x_{i,j+b}, \\ y_{i,j} &= \sum_{a=0}^{k_h-1} u_a t_{i+a,j} = \sum_{a=0}^{k_h-1} \sum_{b=0}^{k_w-1} u_a v_b x_{i+a,j+b}. \end{aligned} \quad (9.40)$$

水平结果 $t_{i,j}$ 可以被多个垂直窗口复用，因此不必为每个二维窗口重新计算整组水平点积。步长一、无空洞且逐轴边界与裁剪一致时，在足够大的网格上，主要成本由每个输出附近的 $k_h k_w$ 项降为约 $k_h + k_w$ 项，代价是保存或流式处理一维中间结果。

取 $\mathbf{u} = \mathbf{v} = (1, 2, 1)^\top$ ，则 $\mathbf{K} = \begin{bmatrix} 1 & 2 & 1 \\ 2 & 4 & 2 \\ 1 & 2 & 1 \end{bmatrix}$ 。对原 4×4 输入，水平滤波先得到 4×2 的中间矩阵，再垂直滤波得到 2×2 输出，图 9.12 列出全部数值。左上输出为 $8 + 2 \times 24 + 40 = 96$ ，与直接二维求和一致。

这个小例子也提醒我们区分局部估算与完整成本。不填充时，中间矩阵尺寸是 $h \times w'$ ，所以两阶段共需 $hw'k_w + h'w'k_h$ 次核心乘法，并不严格等于 $h'w'(k_h + k_w)$ 。本例需要 $4 \times 2 \times 3 + 2 \times 2 \times 3 = 36$ 次，与直接计算的 $2 \times 2 \times 9 = 36$ 次相同；对 100×100 输入，同一核的两阶段成本为 58212 次，直接计算则为 86436 次。图像相对核越大，中间区域的额外边界开销越容易摊薄。




图 9.12 秩一空间核的两阶段计算。水平核与垂直核均为 $(1, 2, 1)$ ，组成 3×3 核 $\mathbf{u}\mathbf{v}^\top$ 。在步长一、无填充条件下，原 4×4 输入先变为 4×2 中间结果，再变为 2×2 输出。该小例子的两阶段核心乘法量仍为三十六次，图示验证的是结果等价，而非每种输入尺寸都能节省计算。

一般核未必秩一。对核作奇异值分解，将第 r 个奇异值吸收到一个向量中，可写成 $\mathbf{K} = \sum_{r=1}^{\rho} \mathbf{u}_r \mathbf{v}_r^\top$ ，其中 ρ 为保留的非零奇异值个数。保留全部非零奇异值时，分解是精确的；计算 ρ 组一维滤波并相加，即可恢复原二维核的输出。在大网格上的每位置主要成本约为 $\rho(k_h + k_w)$ ，只有这比 $k_h k_w$ 足够小，才可能抵消分解与中间读写。只保留较少的奇异值通常会改变输出，属于近似算法，应检查误差或重新训练。这里的空间可分离性也不同于第 9.3.1 节的深度可分离卷积，后者改变了通道连接方式，不能作为任意密集卷积的无损替换。

计算路线	计算过程的改变	适用条件与代价
直接计算	枚举全部局部乘积并累积	适用各种采样设置，乘加量为 $c_{\text{out}}qm$
矩阵化计算	将点积集中为矩阵乘法	普通 GEMM 保持乘加量；Strassen 可减少块乘法，但增加加减与误差敏感性
Toom-Cook	求值、逐点乘法、插值	面向多项式乘积，可能计算不需要的输出系数
Winograd	固定变换恢复小块滤波输出	小核、小步长设置；变换成本及数值条件需核对
FFT	频域乘法后反变换	线性卷积须补零，变换与复数运算有成本
空间可分离核	低秩分解为一维滤波	无损计算要求相应低秩结构；截断分解会改变输出

表 9.1 按计算过程比较卷积算法。矩阵化本身不减少普通乘加量，但提供了选择矩阵乘法算法的入口。前五条路线在精确算术下计算同一目标映射；空间可分离路线还要求核具有相应结构。表中不把显式展开、隐式取数等存储选择作为新的代数算法。

9.2.3.7 工程实现与优化

计算算法确定需要哪些乘积与求和，执行速度还取决于数据如何送入计算单元。**分块** (tiling) 把相邻输出位置和若干通道放在一起计算，在较近的存储中复用它们共用的输入与核，减少重复读取。块越大，复用机会越多，但寄存器和局部存储需求也越高，可能限制并行度。

矩阵化卷积需要决定如何提供式(9.17)中的窗口矩阵。**数据展开** (im2col) 把窗口复制为连续的列，再调用 GEMM；显式保存整个矩阵需要 qm 个元素，还会产生展开读写。**隐式 GEMM** (implicit GEMM) 则从原张量按需形成当前计算块所需的片段，省去完整展开矩阵，代价是加载时的地址计算与边界判断。CUTLASS 给出了这种实现方式¹¹。

另一种选择是**间接卷积** (indirect convolution)：保存指向原输入通道向量的地址，由专用内核沿地址取数，避免复制全部窗口数值。它与隐式 GEMM 的区别在于显式记录取数位置，也需要承担地址表和间接访存的成本；地址表不能直接交给只接收数值矩阵的普通 GEMM 接口¹²。

卷积之后的偏置和逐元素激活还可在写出前完成，这种**算子融合** (operator fusion) 减少中间结果的读写与调用次数。分块、布局和融合可用于不同算法，但收益取决于层形状、精度、硬件及训练或推理条件。选型应测量完整算子的时间、工作区与误差，不能只比较乘法次数。存储层次、并行调度与融合的具体实现留到第六卷“系统”展开。

9.3 网络结构

一次局部求和只能产生一组线性响应。完整网络还需要用多个核形成不同特征，用非线性组合这些特征，按任务保留或汇聚位置，并把最终结果转换为可比较的预测。本节区分各层承担的作用，再考察它们怎样组成网络。

¹¹ NVIDIA, CUTLASS: Implicit GEMM Convolution, URL: https://github.com/NVIDIA/cutlass/blob/main/media/docs/cpp/implicit_gemm_convolution.md (visited on 10/03/2026)

¹² M. Dukhan, *The Indirect Convolution Algorithm* In arXiv preprint arXiv:1907.02129, 2019

9.3.1 卷积层

沿用第 9.2.3 节的输入与核张量形状, 加入偏置 $\mathbf{b} \in \mathbb{R}^{c_{\text{out}}}$ 。空间和核索引从零开始, 通道索引 c, o 从一开始; $x_{i,j,c}$ 、 $w_{a,b,c,o}$ 、 b_o 分别是输入、核与偏置的元素。输出预激活值 $\mathbf{Z} \in \mathbb{R}^{h' \times w' \times c_{\text{out}}}$ 为

$$z_{i,j,o} = b_o + \sum_{c=1}^{c_{\text{in}}} \sum_{a=0}^{k_h-1} \sum_{b=0}^{k_w-1} w_{a,b,c,o} \tilde{x}_{u(i,a),v(j,b),c}, \quad (9.41)$$

$$u(i,a) = is_h - p_t + ad_h, \quad v(j,b) = js_w - p_l + bd_w.$$

随后通常逐元素应用激活, 得到 $h_{i,j,o} = \sigma(z_{i,j,o})$ 。图 9.13 把式中的通道求和展开, 展示同一组输入怎样形成多个输出通道。




图 9.13 三输入、两输出通道的卷积。左侧三张错位叠放的平面共同组成输入张量 $\mathbf{X}$, 蓝、紫、青区分输入通道; 每个输出核的同色切片读取相应通道中高亮的局部窗口。各切片完成局部乘加后, 三项贡献与偏置一起求和, 分别写入右侧输出张量 $\mathbf{Z}$ 的两个通道; 紫、青输出平面分别由核 1、核 2 产生。示意采用 4×4 输入、 2×2 核、步长一和无填充, 输出为 3×3 ; 核在空间位置间共享。

普通卷积层的参数数为

$$p_{\text{conv}} = k_h k_w c_{\text{in}} c_{\text{out}} + c_{\text{out}} \quad (9.42)$$

空间尺寸没有出现在该式中, 却仍出现在式(9.16)的计算量和活动值存储量中。较大图像可以使用相同参数, 但要生成更多响应。参数量、计算量

和中间特征的内存应分别判断。

核为 1×1 时，每个输出只读取同一空间位置的通道向量。**逐点卷积** (pointwise convolution) 因此是所有位置共享的通道变换，可以增加、压缩或混合通道，却不直接扩展空间感受野。**分组卷积** (grouped convolution) 把输入、输出通道分成 g 组，各组只在内部连接；若两类通道数都能被 g 整除，权重数变为 $k_h k_w c_{in} c_{out} / g$ 。若每个输入通道单独使用一个空间核，再接逐点卷积混合通道，就得到一种**深度可分离卷积** (depthwise separable convolution)：将空间处理与通道混合分成两步。在每个输入通道产生一张中间图的设置下，权重数为 $k_h k_w c_{in} + c_{in} c_{out}$ ，但两步施加的结构约束也与普通卷积不同。

多层组合让一个高层单元读取更大的输入范围。沿由局部卷积、局部池化和逐点运算组成的单条串联路径，设第 ℓ 层的有效核尺寸为 e_ℓ 、步长为 s_ℓ ， r_ℓ 表示感受野跨度， j_ℓ 表示相邻响应在原输入上的间距。对一个轴，有

$$r_0 = j_0 = 1, \quad r_\ell = r_{\ell-1} + (e_\ell - 1)j_{\ell-1}, \quad j_\ell = s_\ell j_{\ell-1}. \quad (9.43)$$

新增的 $e_\ell - 1$ 个间隔，每个在原输入上跨越 $j_{\ell-1}$ 个位置，所以要相乘。以两个空洞率一、步长一的 3×3 层为例，沿任一轴代入 $e_1 = e_2 = 3$ 和 $s_1 = s_2 = 1$ ，得到

$$\begin{aligned} r_1 &= 1 + (3 - 1) \times 1 = 3, & j_1 &= 1 \times 1 = 1, \\ r_2 &= 3 + (3 - 1) \times 1 = 5, & j_2 &= 1 \times 1 = 1. \end{aligned}$$

第二层读取三个相邻的第一层响应，它们各覆盖三个原输入位置，覆盖范围每次只平移一个位置，因此合起来是五个位置，而非九个。高、宽两轴分别计算，便得到 5×5 ；再接同样的一层则为 7×7 。

若只把第一层的步长改为二，仍有 $r_1 = 3$ ，但 $j_1 = 2 \times 1 = 2$ ，第二层于是得到 $r_2 = 3 + (3 - 1) \times 2 = 7$ 、 $j_2 = 1 \times 2 = 2$ 。这里第二层窗口内的相邻响应在原输入上相隔两个位置，故覆盖 7×7 。一般地， $j_{\ell-1} = \prod_{a=1}^{\ell-1} s_a$ 是此前各层步长的乘积，空乘积取一；它把当前层的间隔换算回原输入尺度。

这是忽略跨空间统计等非局部操作后的几何感受野；实际梯度和学到的权重可能集中在其中一部分，空洞采样也可能使范围内存在未读取的位置。含归一化的网络还需计入统计量带来的额外依赖，见第 9.3.3 节。填充还会改变感受野中心与边界的对应，不能只检查跨度。

9.3.2 池化层

某个局部区域内出现了一个特征时，后续计算有时只需要其强度，不需要每个位置的响应。**池化**（pooling）按预设规则汇聚窗口内的数值，通常对每个通道独立作用。它与卷积都读取窗口，但标准池化不学习窗口中的权重，也不直接混合通道。

设输出位置 (i, j) 在某通道读取的有效输入位置集合为 $\Omega_{i,j}$ ，其元素个数为 $q_{i,j}$ 。**最大池化**（max pooling）保留窗口内的最大响应，**平均池化**（average pooling）保留窗口内的平均响应：

$$\begin{aligned} y_{i,j,c}^{\max} &= \max_{(u,v) \in \Omega_{i,j}} x_{u,v,c}, \\ y_{i,j,c}^{\text{avg}} &= \frac{1}{q_{i,j}} \sum_{(u,v) \in \Omega_{i,j}} x_{u,v,c}. \end{aligned} \quad (9.44)$$

在式(9.9)上用不重叠的 2×2 窗口、步长二且不填充，分别得到

$$\mathbf{Y}^{\max} = \begin{bmatrix} 6 & 8 \\ 14 & 16 \end{bmatrix}, \quad \mathbf{Y}^{\text{avg}} = \begin{bmatrix} 3.5 & 5.5 \\ 11.5 & 13.5 \end{bmatrix}. \quad (9.45)$$

最大池化侧重最强响应，平均池化反映整体水平。两者都丢失窗口内的部分信息：仅凭 6 不能知道该窗口的其他三个值，仅凭 3.5 也不能知道四个值的排列。

采用相同窗口与完整窗口取整规则时，池化的输出尺寸可由式(9.13)计算。边界规则却要单独核对：最大池化常将无效位置排除，等价于用负无穷填充，而补零会改变全负窗口的最大值；平均池化若把补零位置计入分母，边缘均值会与只除以有效元素数不同。某些接口使用向上取整，并另行处理末尾窗口，不能把这种输出形状与本章的向下取整约定混用。

全局平均池化（global average pooling）把每张特征图汇成一个数，得到通道向量 $\mathbf{r} \in \mathbb{R}^{c_{\text{in}}}$ ：

$$r_c = \frac{1}{hw} \sum_{i=0}^{h-1} \sum_{j=0}^{w-1} x_{i,j,c}. \quad (9.46)$$

全局最大池化则保留每个通道在全部位置上的最大值。若平移仅对特征图作位置置换，例如循环边界上的整数平移，这两种汇聚都保持结果不变。但实际网络中的填充、裁剪和跨步可能使平移后的特征图不再只是原图的置换，因此不能由“使用了全局池化”推出对任意图像平移严格不变。局部池化也只能在特定变化下保留局部响应，不能保证一般平移不变。

9.3.3 激活与归一化

卷积层仍然是仿射映射，单独堆叠不足以学习复杂的非线性关系。ReLU、GELU 或 SiLU 可逐元素作用于特征图，保留空间和通道形状，同时改变局部响应。它们的定义、梯度和初始化配合见第 8.1.2 节。卷积网络中常用 ReLU，并不意味着其他激活不适用；应区分隐藏特征的非线性与输出的概率或取值约束。

深层组合还会改变活动值的尺度。**批归一化** (batch normalization, BN) 用当前小批量的统计量调整特征，再学习一个缩放与平移。对卷积特征，通常按通道在批量轴和两个空间轴上统计；设小批量预激活为 $z_{t,i,j,c}$ 、样本索引 $t = 1, \dots, n_b$ ，统计元素数为 $m = n_b h' w'$ ，则

$$\begin{aligned} \mu_c &= \frac{1}{m} \sum_{t,i,j} z_{t,i,j,c}, & v_c &= \frac{1}{m} \sum_{t,i,j} (z_{t,i,j,c} - \mu_c)^2, \\ \hat{z}_{t,i,j,c} &= \frac{z_{t,i,j,c} - \mu_c}{\sqrt{v_c + \epsilon}}, & \bar{z}_{t,i,j,c} &= \gamma_c \hat{z}_{t,i,j,c} + \beta_c. \end{aligned} \quad (9.47)$$

其中 $\epsilon > 0$ 防止分母过小。固定通道 c 后，均值与方差汇集全部 $n_b h' w'$ 个数值，不跨通道求和；同一组可学习参数 γ_c, β_c 也在这些样本和空间位置之间共享，不为每个像素位置另设一组参数。

全连接前馈网络的 BN 使用相同原则，但没有空间轴。将一个小批量的特征按行排成 $\mathbf{Z}_{\text{FFN}} \in \mathbb{R}^{n_b \times d}$ ，固定特征坐标 q ，就只在 $\{z_{t,q} : t = 1, \dots, n_b\}$ 上统计均值与方差， γ_q, β_q 在样本间共享。因此，FFN 的“特征级”BN 固定一列、跨样本统计，CNN 的“通道级”BN 固定一个通道、跨样本和空间位置统计。若把卷积特征展平成 $n_b \times (h' w' c_{\text{out}})$ 后逐列做 BN，每个空间位置会分别统计并拥有各自的仿射参数，这与卷积 BN 不同。其他归一化方法的统计轴对照见图 14.6。

训练时，共用均值与方差使这些数值的计算相互耦合：一个值改变，可能影响同组其他值的归一化结果。CNN 的这种依赖既跨样本，也跨同一通道的空间位置。推理时通常使用训练中累计的均值与方差，使单样本计算固定。累计方差的具体估计约定应与实现一致。常见组合是“卷积—BN—ReLU”，紧接 BN 的卷积偏置常可省略，因为通道中心化会消除它，BN 另有平移参数¹³。

当批量较小或批内组成变化较大时，可以改变统计范围。**组归一化** (group normalization, GN) 把通道分成若干组，对每个样本分别在每组通道及其空间位置上统计均值和方差，然后仍按通道学习缩放与平移。它不需要其他样本提供统计量，训练和推理使用相同的统计范围，但会让同组通道发生统计耦合。组数是结构设置，通道数需要能够均分。GN 与 BN 改变的是统计对象，不能仅凭名称断言哪一种在所有任务上更好¹⁴。

这些统计量也改变数据依赖范围。训练态 BN 通过通道均值与方差连接

¹³ S. Ioffe, C. Szegedy, *Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift* In Proceedings of the 32nd International Conference on Machine Learning, 2015, pp. 448–456

¹⁴ Y. Wu, K. He, *Group Normalization* In Proceedings of the European Conference on Computer Vision, 2018, pp. 3–19

同批样本的不同空间位置，GN 则在训练和推理时都连接同一样本组内的各空间位置；式(9.43)没有计入这些路径。推理态 BN 若使用固定的运行统计量，就只是逐点仿射变换，不会额外扩大依赖范围。

归一化、激活和池化的顺序影响计算含义。对平均池化，通常有 $\sigma(\text{Avg}(\mathbf{X})) \neq \text{Avg}(\sigma(\mathbf{X}))$ ；例如两个响应为 -2 和 1 时，先平均再 ReLU 得到 0 ，先 ReLU 再平均得到 $1/2$ 。单调逐点激活与不含额外填充值的最大池化可以交换，但加入归一化后不能据此随意调换整个模块。各架构的模块顺序应按定义读取；跨架构的训练机制由后续《神经网络的训练》章展开。

9.3.4 输出和学习目标

预测整张图像类别时，需要把空间特征转换为整体得分。可以将末层特征展平后接全连接层，也可以先作全局平均池化再接分类层。设汇聚向量为 $\mathbf{r}$ ，类别数为 q ，原始得分为 $\mathbf{a} = \mathbf{U}\mathbf{r} + \mathbf{d} \in \mathbb{R}^q$ ，则多类概率与单样本损失为

$$p_k = \frac{\exp(a_k)}{\sum_{v=1}^q \exp(a_v)}, \quad \ell = -\log p_y. \quad (9.48)$$

这里 $y \in \{1, \dots, q\}$ 为图像标签；训练学习卷积特征与分类层参数，使用时取最大得分类别。回归、二分类和多标签输出可以沿用第 8.1.3 节的变换与损失。将最后一张特征图简单当作类别概率，并没有完成这些输出约束。

若要预测每个像素的类别，就需要保留或恢复空间轴。设得分张量为 $\mathbf{A} \in \mathbb{R}^{h \times w \times q}$ ，在每个位置单独应用 Softmax，可得到 $p_{i,j,k}$ 。给定像素标签 $y_{i,j}$ ，逐位置交叉熵为

$$\ell_{\text{seg}} = -\frac{1}{|\Omega|} \sum_{(i,j) \in \Omega} \log p_{i,j,y_{i,j}}. \quad (9.49)$$

其中 Ω 为有标签的位置集合，未标注像素不参与求和。每个位置输出多个颜色值或其他连续量时，可改用回归损失。两种输出任务都用卷积特征，却对空间汇聚有不同要求：分类可以舍去具体位置，分割和图像生成必须保留输出与位置之间的对应。

对 n 个独立训练样本，用 θ 收集所有可学习核、偏置、归一化参数和输出层参数。若网络不含跨样本操作，前向映射可逐样本计算，经验目标可写为

$$\hat{R}_S(\theta) = \frac{1}{n} \sum_{t=1}^n \ell(f_{\theta}(\mathbf{X}_t), \mathbf{Y}_t). \quad (9.50)$$

这里 $\mathbf{Y}_t$ 统指与任务对应的目标；标量类别标签按式(9.48)处理。像素损失可在单张图像内部先汇聚，再在图像之间取平均。

使用固定统计量的推理态 BN 符合上述逐样本前向条件，训练态 BN 则

不符合。给定非空批索引集 B ，将整批输入记为 $\mathbf{X}_B = (\mathbf{X}_t)_{t \in B}$ ，用 $\mathbf{F}_\theta(\mathbf{X}_B)_t$ 表示批预测中对样本 t 的输出。一次更新所用的数据损失为

$$L_B(\theta) = \frac{1}{|B|} \sum_{t \in B} \ell(\mathbf{F}_\theta(\mathbf{X}_B)_t, \mathbf{Y}_t). \quad (9.51)$$

各项损失仍可相加，但每项预测都可能依赖整批输入。求导必须沿完整批计算图回传，包括均值与方差连接不同样本的路径；分别运行单样本前向、求导后再平均，一般不能得到 $\nabla_\theta L_B$ 。若要定义随机分批训练的总体目标，还需给定批抽样规则，再对 L_B 取期望；梯度累积与一次大批前向的区别见第 14.1.3 节。正则项、数据增强和优化策略可以加入训练过程，本章重点是结构特有的梯度与信息传递。

9.3.5 常见卷积网络架构

完整架构要在空间精度、特征种类和计算成本之间分配资源。下采样减少空间位置，高层增加通道可以在较粗网格上保存更多特征；末端再根据任务读出。下面分别介绍 LeNet、AlexNet、VGG 和 GoogLeNet。图中长方体表示特征张量，正面示意空间网格，厚度示意通道维；深色局部块与虚线突出一次局部映射，四角连线帮助追踪相邻张量的形状变化。全连接层用包含圆形神经元的平面方框表示，与卷积主体区分。主路径从左向右展开，实际尺寸写在各层或阶段下方；绘图尺寸不与张量元素数严格成比例。

9.3.5.1 LeNet-5：从局部检测到整体读出

手写字符的局部笔画需要逐渐组合成整字。LeNet-5 交替使用卷积与降采样，先形成小范围响应，再扩大后层能够读取的区域。原网络接收 32×32 的单通道图像，C1 用六个 5×5 核产生 $28 \times 28 \times 6$ 特征；S2 降为 $14 \times 14 \times 6$ ，C3 产生 $10 \times 10 \times 16$ ，S4 再降为 $5 \times 5 \times 16$ 。C5 用覆盖整个 5×5 区域的核得到 120 个整体特征，接 84 单元的 F6，再计算十类输出，见图 9.14¹⁵。

S2 和 S4 不是今天无参数的标准平均池化：每张特征图的局部求和还经过可学习缩放、偏置和非线性。C3 也不是每个输出都连接全部输入通道，而是采用指定的部分连接，使不同输出读取不同的通道组合。C5 虽然空间输出为 1×1 ，仍是卷积层；对这里固定的输入形状，它恰好具有整体连接的作用。

因此，教学中常见的“普通卷积—平均池化—ReLU—Softmax”版本是对 LeNet 的改写。它便于使用现代算子实现，却不保留全部原始设计。阅读这类架构时，应分别识别空间缩小、通道组合和整体读出的职责，再核对版本差别；只按层名照搬，容易把不同年代的训练与输出约定混在一起。

¹⁵ Y. LeCun, L. Bottou, Y. Bengio, P. Haffner, *Gradient-Based Learning Applied to Document Recognition* In Proceedings of the IEEE, 1998, vol. 86, no. 11, pp. 2278–2324




图 9.14 LeNet-5 的层次结构。C1、C3 和 C5 为卷积层，S2、S4 为原网络可学习的降采样层，F6 为全连接层；原始十类读出采用欧氏径向基函数单元。长方体和局部映射均为示意，标签给出实际形状。C3 的部分通道连接与降采样层的可学习参数未在图中逐条展开。

9.3.5.2 AlexNet：扩大容量并组织 GPU 训练

自然图像包含更多颜色、纹理和尺度变化，需要更丰富的局部表示。AlexNet 包含五个卷积层和三个全连接层；隐藏层使用 ReLU，在第一、第二和第五个卷积阶段后作最大池化，在前两个全连接层使用 Dropout。卷积主体输出通道依次为 96, 256, 384, 384, 256，前两层分别用较大核快速扩大覆盖范围，后三层用 3×3 继续组合特征¹⁶。

图 9.15 采用能明确核算形状的 227×227 教学输入约定。所有卷积不使用空洞，卷积与池化的空间尺寸均按式(9.13)向下取整；三次最大池化均为 3×3 窗口、步长二、无填充。首层卷积以 11×11 核、步长四、无填充产生 55×55 输出，池化降到 27×27 ；第二卷积使用 5×5 核、步长一、四周各填充二，保持尺度，池化降到 13×13 ；后三层均为 3×3 核、步长一、四周各填充一，保持该尺度。末次池化形成 $6 \times 6 \times 256$ ，展平为 9216 维，接 4096、4096 和 1000 单元。原论文正文写输入 224×224 ，却展示首层 55 的空间尺寸；在无填充的向下取整规则下二者并不相符。这里显式选用 227，避免把这个版本差异藏在图中。

容量增加也会把成本集中到尾部。仅 9216 维到 4096 维的全连接权重就有 37748736 个，下一层又有 16777216 个；它们与卷积核共享权重的组织不同，是全模型参数数量的重要来源。原实现将网络分配到两块 GPU，部分层限制跨 GPU 的通道连接，这也影响了分组方式。ReLU、数据增强和 Dropout 分别作用于非线性、训练输入变化与正则化；GPU 解决计算可行性，不能代替这些学习设计。AlexNet 的意义在于这些因素共同支撑了大规模监督学习，而不是某一个模块单独保证效果。

¹⁶ A. Krizhevsky, I. Sutskever, G. E. Hinton, *ImageNet Classification with Deep Convolutional Neural Networks* In *Advances in Neural Information Processing Systems* 25, 2012, pp. 1097–1105




图 9.15 AlexNet 的五个卷积层与三个全连接层。全部主路径在一行展开，卷积层、最大池化层与全连接层分别绘出；最后一次池化的输出展平为 9216 维。各层下方给出空间尺寸和通道数，C 表示卷积，P 表示池化。此图采用 227 输入及正文给定的填充约定，省略局部响应归一化、Dropout 和原始双 GPU 的分组细节。

9.3.5.3 VGG：以连续小核组织深度

AlexNet 混合不同核尺寸，VGG 则研究较规则的小核堆叠。主体使用步长一、填充一的 3×3 卷积，在阶段末用 2×2 、步长二的最大池化缩小空间。VGG-16 的五个阶段分别含 2, 2, 3, 3, 3 个卷积层，通道数为 64, 128, 256, 512, 512；加上三个全连接层，共有 16 个带权重的层，池化与激活不计入这个数字。VGG-19 把后三阶段的卷积数增为四，总计 19 个带权重层¹⁷。

连续小核能够逐层扩大感受野。两个步长一的 3×3 层覆盖 5×5 跨度，三个覆盖 7×7 ；若各层通道均为 c 且忽略偏置，两个小核用 $18c^2$ 个权重，单个 5×5 用 $25c^2$ 个。中间激活还增加了一次非线性，因此前者并非后者的精确替换；比较成立的通道假设也不能省略。

这种规则结构便于分阶段核算形状，但高分辨率阶段的活动值与乘加仍然很大，经典 VGG 的 4096 单元全连接尾部也有大量参数。增加深度时仍需合适的训练与正则化。VGG 提供了一种清晰的深度组织方式，并没有自动解决深层串联中的梯度与退化问题。

¹⁷ K. Simonyan, A. Zisserman, *Very Deep Convolutional Networks for Large-Scale Image Recognition* In International Conference on Learning Representations, 2015




图 9.16 VGG-16 的五阶段卷积主体与全连接尾部。每个阶段内的 3×3 卷积保持空间尺寸，阶段末池化减半；图中主体特征标注为池化后的形状。13 个卷积层与三个全连接层组成 16 个带权重的层。每个卷积阶段合并展示其中的卷积堆叠与末端池化，平面神经元框表示全连接层；层下方分别标出空间尺寸与通道数。




图 9.17 三个步长一、无空洞的 3×3 卷积逐层扩大几何感受野。彩色方格表示一个高层位置在原输入上可能读取的范围，中心实色格只用于对齐位置；跨度依次为 3, 5, 7。图没有计入池化、跨位置归一化或边界填充造成的额外依赖。

9.3.5.4 GoogLeNet：在模块内分配多个尺度

连续小核把不同尺度安排在不同深度。若希望同一层同时处理不同范围，可以把输入送入并行分支。**Inception 模块**将同一输入分别交给 1×1 、 3×3 、 5×5 局部处理及池化分支，再沿通道轴拼接。较大核前先用 1×1 压缩通道，池化分支保持空间尺寸后也可用逐点卷积调节通道。各分支需要相同高、宽，通道数则可以不同，见图 9.18。

图中 3×3 分支先将通道从 64 压到 16，再输出 32 个通道，权重数为 $64 \times 16 + 9 \times 16 \times 32 = 5632$ ；直接从 64 映射到 32 需要 18432 个。节省来自中间通道压缩，压缩也会限制该分支的表示。拼接保留分支间的区别，没有像相加那样把对应通道混合；后续卷积再学习如何组合这些通道。

经典 GoogLeNet 先用普通卷积与池化形成 $28 \times 28 \times 192$ 特征，再堆叠九个 Inception 模块，按两、五、两个模块分成三个尺度阶段；两个阶段间池化将空间降为 14 和 7。末端 $7 \times 7 \times 1024$ 特征经全局平均池化形成 1024 维向量，再作 1000 类分类。训练时，在中间层加入辅助分类器，让较浅位置也收到任务损失；推理时使用主分类路径。图 9.19 展示主路径，原论文按最长路径计 22 个带参数层，不能把一个 Inception 模块误计为一个普通卷积层¹⁸。

GoogLeNet 用多分支增加同层处理方式，用逐点卷积控制大核分支的成本，并以全局汇聚替代庞大的全连接尾部。代价是分支调度、拼接和更多中间特征，理论乘加预算仍需结合实现分析。表 9.2 把四种架构放回共同的问题：它们如何从局部形成整体表示，又将计算与参数放在何处。

¹⁸ C. Szegedy, W. Liu, Y. Jia, P. Sermanet, S. Reed, D. Anguelov, D. Erhan, V. Vanhoucke, A. Rabinovich, *Going Deeper with Convolutions* In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2015, pp. 1–9




图 9.18 一个 Inception 模块的四分支教学配置。输入为 $28 \times 28 \times 64$ ；四条分支分别输出 16、32、16、16 个通道，保持同一空间尺度，拼接得到 $28 \times 28 \times 80$ 。中间的逐点卷积先压缩通道，最大池化采用步长一及 same 填充。圆角方框表示处理算子，Max 为最大池化，线路上的数字为通道数；圆形 + 表示沿通道拼接，四条路径实际并行，激活省略。




图 9.19 经典 GoogLeNet 的主分类路径。卷积前端把 224×224 输入变成 $28 \times 28 \times 192$ ；两个、五个、两个 Inception 模块组成三个阶段，阶段间池化改变空间尺度。各阶段末的通道数为 480、832 和 1024，全局平均池化后接 1000 类分类器。辅助分类分支及模块内部细节省略，模块内部结构见图 9.18。

架构	主体组织	理解结构时的侧重点
LeNet	卷积与可学习降采样交替	局部到整体；部分连接及原始输出约定
AlexNet	五个卷积层与较大全连接尾部	通道容量、训练机制、GPU 分组及尾部成本
VGG	连续小核，阶段间池化	感受野、深度、规则结构及活动值成本
GoogLeNet	多尺度分支、通道压缩与拼接	同层并行处理、计算预算与整体汇聚

表 9.2 经典卷积网络的组织方式。各行比较计算结构，没有在不同训练设置之间比较准确率。层数、输入形状和读出方式均应结合具体版本理解。

9.4 参数学习

卷积网络仍按前章的链式法则学习。结构带来的区别是：一个核权重在许多位置出现，一个输入又可能被多个窗口读取。因此，初始化应按局部连接数定尺度，反向传播则必须汇总所有重复使用的贡献。

9.4.1 参数初始化

对普通卷积，一个输出单元读取 $k_h k_w c_{in}$ 个值，故通常取

$$\text{fan-in} = k_h k_w c_{in}, \quad \text{fan-out} = k_h k_w c_{out}. \quad (9.52)$$

后者按内部位置、步长为一的连接估计，每个输入向多个输出位置及通道贡献；边界、跨步和分组会改变实际连接数。初始化实现一般采用固定的核级约定，应区分这一约定与每个位置的精确计数。

设初始权重独立、零均值、方差为 v ，与输入独立，偏置为零，各输入元素二阶矩为 q 。不同权重的交叉项均值为零，即使相邻像素相关，仍可在这个初始化模型下得到

$$\mathbb{E}[z_{i,j,o}^2] = k_h k_w c_{in} v q$$

用于内部位置的尺度估计。若预激活分布关于零对称，ReLU 截去负半轴会使二阶矩减半，所以前向 He 初始化取

$$w_{a,b,c,o} \sim \mathcal{N}\left(0, \frac{2}{k_h k_w c_{in}}\right). \quad (9.53)$$

这与前章一致，分母变为局部输入连接数，而非整张图像的像素数。偏置可以初始化为零；不同核仍需要不同的随机权重，以打破输出通道之间的对称性¹⁹。

对中心附近近似单位斜率的激活，Glorot 初始化可用方差 $2/(\text{fan-in} + \text{fan-out})$ 折中前后向尺度。分组层的局部 fan-in 需除以组数；只有一个空间核的逐通道层，每个输出读取 $k_h k_w$ 个值。跨步卷积中，每个输入参与的输出窗口更少且可能随位置变化，简单独立性估计也不会捕捉共享权重

¹⁹ K. He, X. Zhang, S. Ren, J. Sun, *Delving Deep into Rectifiers: Surpassing Human-Level Performance on ImageNet Classification* In Proceedings of the IEEE International Conference on Computer Vision, 2015, pp. 1026–1034

造成的空间相关。初始化提供的是起始尺度依据，训练中还需检查实际活动值与梯度，不能把这些近似当成全过程保证。

9.4.2 卷积层反向传播

以式(9.51)的批平均损失 L_B 为求导对象，记上游传到卷积预激活的梯度为 $\delta_{t,i,j,o} = \partial L_B / \partial z_{t,i,j,o}$ ，其中 $t \in B$ 。这个导数包含整批所有损失项的影响，不只是样本 t 自身的损失。若已知的是紧接卷积的激活输出梯度，需先乘 $\sigma'(z_{t,i,j,o})$ ；若中间还有归一化，则按前向相反顺序对其求导。特别是训练态 BN，必须经过完整批统计量的计算图，才能取得这里的 δ 。以下采用式(9.41)，并固定零填充约定。

同一权重 $w_{a,b,c,o}$ 在各样本及各输出位置重复使用，因此链式法则给出

$$\begin{aligned} \frac{\partial L_B}{\partial w_{a,b,c,o}} &= \sum_{t \in B} \sum_{i=0}^{h'-1} \sum_{j=0}^{w'-1} \delta_{t,i,j,o} \tilde{x}_{t,u(i,a),v(j,b),c}, \\ \frac{\partial L_B}{\partial b_o} &= \sum_{t \in B} \sum_{i=0}^{h'-1} \sum_{j=0}^{w'-1} \delta_{t,i,j,o} \end{aligned} \quad (9.54)$$

每个位置都提出一项局部更新意见，共享参数将这些意见相加。不同位置的贡献可以相互加强，也可以抵消；参数共享并不要求所有位置产生相同响应或相同梯度。这里 δ 已包含批平均的 $1/|B|$ ，汇总时不再除以批量大小。只有前向映射逐样本独立时，才可先由单样本损失分别求导，再在批量上平均。

一个卷积输入 $x_{t,u,v,c}$ 可能参与本样本的多个输出窗口，也可能连接多个输出通道。将卷积局部映射中所有包含它的项找出，得到

$$\frac{\partial L_B}{\partial x_{t,u,v,c}} = \sum_{i,j,o} \delta_{t,i,j,o} w_{a,b,c,o} \mathbb{I}\{u = u(i,a), v = v(j,b)\}. \quad (9.55)$$

其中 u, v 在原输入范围内， $\mathbb{I}$ 为条件成立时取一的指示函数，求和范围沿用前向计算。该式适用于跨步和空洞，不需要凭印象猜核应当翻转几次。若使用复制或反射填充，一个原输入还可能对应多个扩展位置，需把这些位置的梯度再累加回来；不能将零填充下的单一索引条件直接照搬。

矩阵形式揭示了它与转置卷积的联系。固定参数时，将每个样本的张量展平，前向预激活为 $\mathbf{z}_t = \mathbf{C}\mathbf{x}_t + \mathbf{b}_{\text{rep}}$ ， $\mathbf{b}_{\text{rep}}$ 表示各位置重复的偏置；把 $\delta_{t,i,j,o}$ 展平为 δ_t ，就有

$$\nabla_{\mathbf{x}_t} L_B = \mathbf{C}^\top \delta_t. \quad (9.56)$$

输入梯度正是前向线性算子的转置作用。数据展开实现则先把每个窗口的梯度算出来，再把各列放回输入坐标，并累加重叠部分；这个回填步骤常称为 col2im，它不是把重复窗口无条件复制回去。

仍用式(9.9)，取仅含这一个输入的批量，不加归一化、不填充、步长一，令 L_B 为全部互相关输出之和。九个输出的 δ 均为一，则

$$\nabla_{\mathbf{K}} L_B = \begin{bmatrix} 54 & 63 \\ 90 & 99 \end{bmatrix}, \quad \nabla_{\mathbf{X}} L_B = \begin{bmatrix} 1 & 1 & 1 & 0 \\ 1 & 0 & 0 & -1 \\ 1 & 0 & 0 & -1 \\ 0 & -1 & -1 & -1 \end{bmatrix}. \quad (9.57)$$

例如左上核权重汇总九个窗口的左上元素，和为 54； $x_{1,1} = 6$ 既以系数 1 参与一个窗口，也以系数 -1 参与另一个窗口，两项相消。虽然某些核权重当前为零，它们的梯度仍可非零，因为改变该权重会立即改变相应输出。偏置梯度为 9。这个例子把“共享参数累积”与“重叠输入累积”区分开来。

9.4.3 池化层反向传播

池化没有标准的可学习参数，但它决定上游梯度怎样返回输入。仍对完整批损失求导，设池化输出的梯度为 $g_{t,i,j,c} = \partial L_B / \partial y_{t,i,j,c}$ 。平均池化对每个参与的元素具有相同导数，因此

$$\frac{\partial L_B}{\partial x_{t,u,v,c}} = \sum_{i,j} \frac{g_{t,i,j,c}}{q_{i,j}} \mathbb{I}\{(u,v) \in \Omega_{i,j}\}. \quad (9.58)$$

分母必须与前向平均采用的计数相同。窗口重叠时，一个输入收到多项；全局平均池化则将某通道的上游梯度均分给该通道全部位置。

最大池化在最大值唯一时，只对被选中的元素有非零导数。前向计算记录其位置 $(u_{t,i,j,c}^*, v_{t,i,j,c}^*)$ ，后向使用同一位置：

$$\frac{\partial L_B}{\partial x_{t,u,v,c}} = \sum_{i,j} g_{t,i,j,c} \mathbb{I}\{(u,v) = (u_{t,i,j,c}^*, v_{t,i,j,c}^*)\}. \quad (9.59)$$

若多个元素并列最大，函数在该点不可微；实现可以按固定规则选择一个位置，也可以采用最大值集合上的合法次梯度分配。必须保持前后向约定一致。同一元素若是多个重叠窗口的最大值，会收到这些窗口梯度的和。

对式(9.45)，令四个输出梯度均为一。平均池化使每个输入收到 1/4，最大池化只让原矩阵中的 6, 8, 14, 16 各收到 1。回传规则因此保留了两种汇聚方式的差别：平均把影响均分，最大把影响路由到当前胜出的位置。卷积与池化梯度接入前章的反向传播后，就能联合更新整个网络；优化器和学习率的通用选择由后续训练章讨论。

9.5 支持更深的网络结构

连续堆叠卷积可以扩大感受野并增加非线性组合，却也使信息和梯度经过更长的变换链。前章已说明，雅可比连乘可能放大或衰减梯度。即使初始化和归一化让训练开始收敛，更深的普通串联网络仍可能出现更高的训练误差。这里的**退化问题**（degradation problem）指增加层数后训练效果反而下降，不能仅用训练集外的过拟合来解释。ResNet 论文在其图像实验中报告并研究了这一现象²⁰。

跨层连接允许部分信息绕过某些变换。下面比较三种组织方式：直接相加、用门选择相加，以及保留旧特征再拼接新特征。它们都可以保持前馈计算，但改变了中间表示和梯度路径。

²⁰ K. He, X. Zhang, S. Ren, J. Sun, *Deep Residual Learning for Image Recognition* In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2016, pp. 770–778

9.5.1 残差连接与 ResNet

若新增的一组层暂时无须改变输入，普通串联模块仍要学出恒等映射。**残差连接**（residual connection）把输入直接加到变换分支的结果上，使该分支只学习相对于输入需要改动的部分。将输入特征展平为 $\mathbf{x} \in \mathbb{R}^d$ ，维度相同时，模块写为

$$\mathbf{y} = \mathbf{x} + \mathbf{F}_{\theta}(\mathbf{x}). \quad (9.60)$$

其中 $\mathbf{F}_{\theta} : \mathbb{R}^d \rightarrow \mathbb{R}^d$ 由若干卷积、归一化和激活组成。若目标映射接近恒等，残差分支只需接近零。这里的“残差”是模块输出相对于输入的差，不是标签减去预测值的训练误差。

图 9.20 展开一个基本模块中的层与残差连接。上方旁路把输入直接送到加法节点，主分支则计算需要叠加的变换；图中的模块还在相加后施加一次 ReLU。




图 9.20 残差基本模块中的逐层变换与恒等旁路。主分支依次经过 3×3 卷积、BN、ReLU 及第二个 3×3 卷积、BN，再与直接传来的输入逐元素相加并激活。两次卷积均保持 $32 \times 32 \times 64$ 形状，上方蓝色旁路跳过主分支的变换。圆角方框表示算子，圆形加号节点表示逐元素相加；改变尺度或通道时，旁路需要投影。

下面只考察相加本身，暂不在相加后施加额外激活；含训练态 BN 时， $\mathbf{x}$ 应包含参与统计的整批特征。在可微位置，令 $\mathbf{J}_F = \partial \mathbf{F} / \partial \mathbf{x}$ 。输入的微小

变化 $\mathbf{dx}$ 沿两条路径分别产生 $\mathbf{dx}$ 与 $\mathbf{J}_F \mathbf{dx}$ ，相加后有

$$d\mathbf{y} = \mathbf{dx} + \mathbf{J}_F \mathbf{dx} = (\mathbf{I} + \mathbf{J}_F) \mathbf{dx}。$$

对标量损失 ℓ ，链式法则给出 $d\ell = (\nabla_{\mathbf{y}} \ell)^\top d\mathbf{y}$ 。代入上式，再与 $d\ell = (\nabla_{\mathbf{x}} \ell)^\top \mathbf{dx}$ 比较，就得到

$$\begin{aligned} \frac{\partial \mathbf{y}}{\partial \mathbf{x}} &= \mathbf{I} + \mathbf{J}_F, \\ \nabla_{\mathbf{x}} \ell &= (\mathbf{I} + \mathbf{J}_F)^\top \nabla_{\mathbf{y}} \ell \\ &= \nabla_{\mathbf{y}} \ell + \mathbf{J}_F^\top \nabla_{\mathbf{y}} \ell。 \end{aligned} \quad (9.61)$$

末行的第一项直接经过恒等路径，第二项经过残差分支。但两项仍可能相消，例如标量分支 $F(x) = -x$ 就有 $1 + F'(x) = 0$ 。多块连乘也可能放大或衰减梯度，因而这不是“永不消失”的保证。

若记相加结果为 $\mathbf{z} = \mathbf{x} + \mathbf{F}(\mathbf{x})$ ，再令 $\mathbf{y} = \text{ReLU}(\mathbf{z})$ ，则反向还要先经过 ReLU：

$$\nabla_{\mathbf{x}} \ell = (\mathbf{I} + \mathbf{J}_F)^\top \mathbf{D}_{\text{ReLU}} \nabla_{\mathbf{y}} \ell。$$

在 $z_i \neq 0$ 处， $\mathbf{D}_{\text{ReLU}}$ 的第 i 个对角元素为 $\mathbb{I}\{z_i > 0\}$ ；零点按实现选定导数。恒等路径的贡献也会受这层筛选，不能把相加前后的输出混为一谈。

当阶段间下采样或改变通道时，输入与分支结果不能直接逐元素相加。可用投影 $\mathbf{P}$ 调整形状，写为 $\mathbf{y} = \mathbf{Px} + \mathbf{F}(\mathbf{x})$ ；例如用跨步 1×1 卷积同时改变空间尺寸与通道。此时跨层路径的雅可比是 $\mathbf{P}$ ，不再是 $\mathbf{I}$ ，相加本身的雅可比相应变为 $\mathbf{P} + \mathbf{J}_F$ 。选择恒等或投影，取决于两条分支的形状和希望保留的映射。

ResNet 在多个阶段堆叠残差模块。基本模块常用两个 3×3 卷积；瓶颈模块用 1×1 压缩通道、 3×3 处理空间、再用 1×1 恢复通道，以控制主体计算。经典版本在相加后使用激活。比较不同版本时，应核对跳跃路径是否保持恒等，以及下采样究竟位于哪一条分支；仅写“使用残差”还不足以确定计算图。

ResNet-18 的主干分为四个阶段：对 224×224 输入，前端 7×7 卷积取步长二、填充三，产生 112×112 特征；接 BN、ReLU 及 3×3 、步长二、填充一的最大池化，得到 56×56 网格。四个阶段分别使用 64、128、256、512 个通道，每个阶段包含两个基本模块；后三阶段的首模块将空间减半，并用投影匹配相加形状。末端全局平均池化与分类层完成整体读出。

9.5.2 门控连接与 Highway 网络

直接相加始终保留输入并叠加变换；若希望根据当前输入控制两条路径的比例，可以让网络学习一个门。Highway 网络 (Highway network) 用控制

门调节哪些坐标更多采用新变换、哪些更多保留原值。维度相同、保留门与变换门互补时,

$$\begin{aligned} \mathbf{g}(\mathbf{x}) &= \text{Sigmoid}(\mathbf{G}(\mathbf{x})), \\ \mathbf{y} &= \mathbf{g}(\mathbf{x}) \odot \mathbf{F}(\mathbf{x}) + (\mathbf{1} - \mathbf{g}(\mathbf{x})) \odot \mathbf{x}. \end{aligned} \quad (9.62)$$

其中 $\mathbf{F}$ 为变换路径, $\mathbf{G}$ 产生与输入同形状的门得分, Sigmoid 逐元素把门值限制在 (0,1)。在卷积模块中, $\mathbf{F}$ 和 $\mathbf{G}$ 都可使用共享局部计算。门值接近零时以保留路径为主, 接近一时以变换路径为主。原工作采用负的门偏置, 使初始门倾向保留输入, 帮助很深的网络开始学习²¹。

门也依赖输入, 所以求导不能把它当成常数。记 $\text{Diag}(\mathbf{v})$ 为以向量 $\mathbf{v}$ 作对角线的矩阵, $\mathbf{J}_g$ 为门的雅可比, 则

$$\begin{aligned} \mathbf{J}_y &= \text{Diag}(\mathbf{g})\mathbf{J}_F + \text{Diag}(\mathbf{1} - \mathbf{g}) \\ &\quad + \text{Diag}(\mathbf{F}(\mathbf{x}) - \mathbf{x})\mathbf{J}_g. \end{aligned} \quad (9.63)$$

末项来自门值随输入变化的影响。负偏置使门初始更接近保留路径, 也可能让 Sigmoid 进入导数较小的区域, 门参数的学习仍需合适尺度。Highway 增加了可学习的路由及其参数成本; 式(9.62)中两条系数之和为一, 与 ResNet 无门控的直接相加具有不同约束。

图 9.21 展开变换、门和保留路径, 两个逐元素乘法节点分别调节变换结果与原输入, 再由相加节点合并。三条路径都保持 $h \times w \times c$ 形状, 门按位置和通道决定缩放系数; 若设计需要改变形状, 应先明确保留路径的投影及门的目标形状, 不能直接套用同维公式。

²¹ R. K. Srivastava, K. Greff, J. Schmidhuber, *Highway Networks* In ICML Deep Learning Workshop, 2015




图 9.21 同形状卷积 Highway 模块。上方卷积与 ReLU 产生 $F(x)$ ，门路径经卷积与 Sigmoid 产生 g ，蓝色保留路径传递原输入；两个 $\odot$ 节点分别计算 $g \odot F(x)$ 和 $(1-g) \odot x$ ，再由 $+$ 节点相加。所有特征与门具有同一空间、通道形状，圆角方框表示各条路径的处理算子。

9.5.3 密集连接与 DenseNet

残差相加把旧特征和新特征合在相同通道中。若希望后层仍能分别读取先前各层的特征，可以沿通道轴保留它们。**密集连接**（dense connection）使一个块内的每层读取全部先前层的输出；DenseNet 按这种方式构造卷积模块：

$$H^{(\ell)} = F_{\ell}([H^{(0)}, H^{(1)}, \dots, H^{(\ell-1)}])。 \quad (9.64)$$

方括号表示通道拼接，不是逐元素相加；块内空间高、宽必须一致。 $H^{(0)}$ 为块的输入，各层只产生新的通道，旧特征仍可供更后层直接读取²²。

若块输入有 c_0 个通道，每层新增 k 个通道， k 称为**增长率**（growth rate），即每层增加的特征数。第 ℓ 层输入有 $c_0 + (\ell - 1)k$ 个通道，包含 L 层的整个块输出有 $c_0 + Lk$ 个通道。以 $c_0 = 32, k = 16, L = 4$ 为例，各层依次读取 32, 48, 64, 80 个通道，最终拼接得到 96 个通道。块间的**过渡层**（transition layer）用逐点卷积压缩通道，再通过池化降低空间尺寸，限制持续增长的特征规模。

密集连接提供直接的特征读取和梯度路径，但需要保留更多活动值。若每层只用一个产生 k 个新通道的 3×3 卷积，忽略偏置，块内权重数为

$$9k \sum_{\ell=1}^L (c_0 + (\ell - 1)k) = 9k \left(Lc_0 + \frac{kL(L-1)}{2} \right)。 \quad (9.65)$$

固定增长率下，这个简化块的通道相关成本随层数呈二次增长；瓶颈和压缩设计会改变具体成本。残差模块维持相加后的通道数，密集模块保留旧

²² G. Huang, Z. Liu, L. van der Maaten, K. Q. Weinberger, *Densely Connected Convolutional Networks* In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2017, pp. 4700–4708




图 9.22 DenseNet 的三层教学密集块。各 F_ℓ 依次执行 BN、ReLU 和 3×3 卷积，保持 32×32 空间网格并新增 16 个通道。三次变换分别读取 32、48、64 个通道；上方旁路保留变换前的全部特征，标出的 32、48、64 为累计通道数；卷积下方的 16 为新增通道数。圆形 + 将新旧特征沿通道拼接，最终得到 80 个通道。逐次累积拼接等价于保留并向后传递全部先前层的输出，不作逐元素相加。

通道并增加新通道，二者对特征复用、活动值内存和计算的取舍不同，不能仅按跨层连接的数量判断效率。

图 9.22 从左向右展示一个三层教学密集块：32 个初始通道加上三组 16 个新通道，输出为 80 个通道。每次变换前的全部特征经旁路保留，再与本层新产生的通道拼接，因而后层仍能读取每个先前层的输出。若在块后接过渡层，可用 1×1 卷积把 80 个通道压缩为 40 个，再通过池化把 32×32 空间网格缩为 16×16 。

9.6 理论分析

卷积、池化和跨层连接改变了候选函数及其学习过程，但训练误差降低仍不能独自说明新图像上的风险。这里以期望风险与经验风险之间的差为泛化分析对象。假设 n 个训练样本独立同分布地来自 $\mathcal{P}$ ，测试样本也来自 $\mathcal{P}$ ，架构和参数约束在抽样前确定；数据相关约束需要另加选择代价。以下分别讨论数据、参数和结构，避免把某一个因素单独当作泛化保证。

9.6.1 输入与数据对泛化的影响

样本量首先要按独立信息的来源计数。同一图像中的像素、重叠裁块或同一段视频中的相邻帧通常相关；若理论假设独立图像，不能把一张图像的百万个像素当作百万个独立训练样本。按位置重复使用参数增加了学习信号的来源，但没有自动满足独立同分布条件。训练集与测试集也应按原始图像、对象或采集来源划分，避免高度相关的样本跨越划分边界。

输入尺寸与尺度需要一起分析。若每个输入元素的绝对值不超过 a ，展开图像的欧氏范数只能粗略保证 $\|\mathbf{x}\|_2 \leq a\sqrt{hwc_{\text{in}}}$ 。增大分辨率可能增加有用细节，也可能在范数界中增加复杂度项。按整张图像归一化可以控制

总范数，却改变了局部数值尺度；逐通道标准化并不必然控制整图范数。较高分辨率下，固定像素大小的卷积核还覆盖较小的相对区域，因此输入尺寸也改变了结构与任务的配合。

参数共享有价值的条件，是不同位置确实可以由相近规则处理。若同一物体的平移应保持分类标签，共享局部特征与整体汇聚与任务相符；若目标是判断标记是否位于图像左侧，完全舍去位置的读出就可能丢失目标所需信息。对分割，目标轮廓随输入平移，等变表示更贴近输出关系。固定位置、边界和尺度差异都可能使同一个局部图案在不同位置具有不同含义。

可以用一个受限模型把样本量与尺度的作用算清楚。此处只研究单通道标量得分，省去激活和偏置，并在局部线性响应之后作全局平均。设展平输入为 $\mathbf{x} \in \mathbb{R}^d$ ，第 r 个窗口的取数矩阵为 $\mathbf{P}_r \in \mathbb{R}^{q \times d}$ ，共有 m 个窗口。采用零填充且每个窗口内不重复读取同一坐标，定义平均窗口向量

$$\boldsymbol{\phi}(\mathbf{X}) = \frac{1}{m} \sum_{r=1}^m \mathbf{P}_r \mathbf{x}, \quad f_{\mathbf{w}}(\mathbf{X}) = \mathbf{w}^\top \boldsymbol{\phi}(\mathbf{X}). \quad (9.66)$$

其中 $\mathbf{w} \in \mathbb{R}^q$ 为共享核权重。假设抽样前固定 $\|\mathbf{w}\|_2 \leq \alpha$ ，输入满足 $\|\mathbf{x}\|_2 \leq r_x$ 。取数不会增大单个窗口的范数，再由三角不等式有 $\|\boldsymbol{\phi}(\mathbf{X})\|_2 \leq r_x$ 。对独立随机符号 $\varepsilon_t \in \{-1, +1\}$ ，经验 Rademacher 复杂度满足

$$\begin{aligned} \hat{\mathfrak{R}}_S(\mathcal{H}) &= \frac{\alpha}{n} \mathbb{E}_\varepsilon \left\| \sum_{t=1}^n \varepsilon_t \boldsymbol{\phi}(\mathbf{X}_t) \right\|_2 \\ &\leq \frac{\alpha}{n} \sqrt{\sum_{t=1}^n \|\boldsymbol{\phi}(\mathbf{X}_t)\|_2^2} \leq \frac{\alpha r_x}{\sqrt{n}}. \end{aligned} \quad (9.67)$$

这里 $\mathcal{H}$ 是满足该核约束的函数空间。等号来自欧氏球上线性函数的最大值，第一条不等式来自均方根上界，交叉项因随机符号独立而消失。窗口数 m 没有显式出现，因为我们控制了平均后的特征范数；这不表示窗口产生了 m 倍独立样本。

若损失取值于 $[0, 1]$ 、对得分具有 Lipschitz 常数 λ_{loss} ，并满足第二卷“基础、理论和可信性”的“二分类学习的可学习性”章“Rademacher 复杂度给出的期望风险上界”定理的可测性条件，由收缩引理和经验复杂度风险界，以至少 $1 - \delta$ 的概率，对全部上述模型有

$$R(f) \leq \hat{R}_S(f) + \frac{2\lambda_{\text{loss}}\alpha r_x}{\sqrt{n}} + 3\sqrt{\frac{\log(2/\delta)}{2n}}. \quad (9.68)$$

其中 $\delta \in (0, 1)$ 为失效概率， R 与 $\hat{R}_S$ 使用同一损失。这个界让样本数、输入尺度和核约束各自承担明确作用；它不直接覆盖任意深层 CNN，也不直接适用于无界交叉熵。若平均汇聚已经删掉标签需要的位置差异，复杂度很小的模型也可能具有较大的逼近误差。学习判断仍需结合式(8.44)中

的逼近、估计和优化三项。

9.6.2 参数对泛化的影响

卷积的参数规模由核尺寸与通道数决定，空间共享限制了独立可调的自由度。对固定有限的分段线性架构，可以把参数数和计算结构代入相应容量分析，但还需保留深度、计算单元及共享方式的条件；不能只把一个全连接网络的计数结论替换成卷积参数数。理论部分的 VC 分析提供最坏情形工具，实际得到的界也可能很松。

参数范数提供另一种约束。一个核展平后得到的 $\mathbf{W}_{\text{loc}}$ 描述单个窗口的映射，整个卷积层的 $\mathbf{C}$ 却还包括窗口重复与重叠。两者的谱范数一般不同。以步长一、循环边界的一维核 $(1, 1)$ 为例，局部行向量范数为 $\sqrt{2}$ ；输入为常数向量时，整层将该向量放大两倍，整层算子范数实际为 2。把核的展平范数直接称为整层谱范数，会漏掉重叠作用。

这个区别可以通过数据展开估计。设一个原输入坐标最多被 μ 个窗口读取，把所有窗口堆成向量的取数映射记为 $\mathbf{E}$ 。零填充下，每个坐标至多被重复 μ 次，所以 $\|\mathbf{E}\|_2 \leq \sqrt{\mu}$ 。各窗口再独立应用同一局部矩阵，便有

$$\|\mathbf{C}\|_2 \leq \sqrt{\mu} \|\mathbf{W}_{\text{loc}}\|_2 \leq \sqrt{\mu} \|\mathbf{W}_{\text{loc}}\|_{\text{F}} \quad (9.69)$$

其中 $\|\cdot\|_{\text{F}}$ 为 Frobenius 范数。普通步长一的二维窗口有 $\mu \leq k_h k_w$ ；跨步和边界会改变重复次数，复制填充还需重新统计坐标复用。这是一个便于解释的上界，不保证紧。

在步长一、循环边界的条件下，傅里叶基可以将卷积化为各频率上的通道映射。对每个离散频率 (ω_1, ω_2) ，记核对应的复矩阵为 $\widehat{\mathbf{W}}(\omega_1, \omega_2) \in \mathbb{C}^{c_{\text{out}} \times c_{\text{in}}}$ ，则

$$\|\mathbf{C}\|_2 = \max_{\omega_1, \omega_2} \sigma_{\max}(\widehat{\mathbf{W}}(\omega_1, \omega_2)) \quad (9.70)$$

这里 $\sigma_{\max}$ 是最大奇异值，频域核使用与该卷积映射一致的变换约定。Sedghi 等系统研究了这种卷积奇异值表示；有限图像的零填充、裁剪或跨步会改变线性算子，不能直接把循环边界的精确等式套用过去²³。

对普通串联网路，若激活是 1-Lipschitz，固定网络的输入扰动放大可由各层算子范数的乘积控制；归一化和池化则需计入自己的常数。深层泛化界通常还需要结合其他范数、分类间隔、输入尺度或函数空间的覆盖量，详见第二卷“基础、理论和可信性”的“深度学习的可学习性”章“基于参数大小的可学习性”节。限制单层范数只控制其中一部分；将全部得分缩小也会缩小分类间隔，不能仅因参数数值变小就认定分类风险更低。

²³ H. Sedghi, V. Gupta, P. M. Long, *The Singular Values of Convolutional Layers* In International Conference on Learning Representations, 2019

9.6.3 网络结构对泛化的影响

局部连接与参数共享通过限制候选映射减少自由度。如果在相同输入输出、相同后续层和相容参数约束下，把一个不共享权重的局部网络限制为所有位置共用权重，就得到其中一个子空间；复杂度不会因这种限制而增大。但子空间可能排除目标需要的规则。结构匹配时，这种限制可以减少估计负担；结构失配时，逼近误差可能增加。这才是卷积归纳偏置与泛化之间的有条件联系。

深度与通道宽度同时改变表示能力、参数约束和传播路径。增加通道可以保留更多局部特征，增加深度可以组合更大范围的信息；若各层范数随之变化，相应复杂度控制也会变化。式(9.68)中没有显式出现通道宽度，并不说明任意加宽的深层网络都保留同样的界。要比较架构，应固定任务、输入尺度、损失和约束，再检查新增的候选函数与路径。

跨层连接还改变固定网络的敏感度。为单独考察合并操作，假设残差分支 $\mathbf{F}$ 的 Lipschitz 常数不超过 λ_F ，忽略额外的归一化与输出激活，则

$$\text{Lip}(\mathbf{x} + \mathbf{F}(\mathbf{x})) \leq 1 + \lambda_F. \quad (9.71)$$

残差块提供直接路径，但连续多个块的粗略上界仍为 $\prod_{\ell}(1 + \lambda_{F_{\ell}})$ 。若分支缩放为 $\alpha_{\ell}\mathbf{F}_{\ell}$ ，相应因子变成 $1 + |\alpha_{\ell}|\lambda_{F_{\ell}}$ 。这个计算说明路径及尺度怎样影响扰动，也说明残差连接并不会自动使理论复杂度更小。

对密集结构，把保留的全部特征作为当前状态 $\mathbf{s}$ ，一次新增特征可写成 $\mathbf{s}' = [\mathbf{s}, \mathbf{F}(\mathbf{s})]$ 。使用拼接后各坐标的欧氏范数，有

$$\|\mathbf{s}'_1 - \mathbf{s}'_2\|_2^2 \leq (1 + \lambda_F^2)\|\mathbf{s}_1 - \mathbf{s}_2\|_2^2. \quad (9.72)$$

因子与相加的情形不同，状态维度也不断增长。拼接后卷积的局部输入通道数、范数约束和过渡层均要随之计入。Highway 还涉及门的输入导数，式(9.63)中的末项不能省去。相加、拼接与门控各自改变了分析对象，没有仅凭连接名称成立的泛化排序。

池化的作用也依赖窗口是否重叠。对不重叠窗口，最大池化在欧氏范数下至多为 1-Lipschitz；大小均为 q 的平均池化至多为 $1/\sqrt{q}$ -Lipschitz。因为一个窗口的最大值差不超过该窗口输入差的最大绝对值，而平均值差可由 Cauchy-Schwarz 不等式控制，再将不重叠窗口平方求和即可得到这些界。若窗口重叠，同一个坐标重复参与输出，需要额外考虑覆盖次数。汇聚减少位置细节、可能降低敏感度，也可能损失分割边界所需的信息。

这些敏感度估计还不是独立的泛化定理。函数空间的复杂度与算法稳定性考察不同对象：前者控制允许的所有候选函数，后者控制更换训练样本后的学习结果。卷积参数共享改变了两者可能用到的量，但稳定性分析

仍需说明优化器、步长、停止时刻和损失条件。若部署图像来自不同设备或场景，前面的同分布界也不足以覆盖这一变化，需要承接迁移学习与可信性部分的分布分析。

9.7 常见应用

分类把整张图像压成一个答案，而分割和图像生成需要输出一张新的空间图。两类任务都可以使用**编码器—解码器**（encoder-decoder）结构：编码器逐步把输入变成较粗但通道更丰富的特征，解码器再逐步恢复输出网格。恢复分辨率只增加输出位置，并不能自动找回下采样中丢失的细节，因此还需要考虑哪些中间特征应当保留。

9.7.1 图像分割

图像分割为每个位置预测类别，例如区分医学图像中的组织区域。输入为 $\mathbf{X} \in \mathbb{R}^{h \times w \times c_{in}}$ ，目标标签矩阵为 $\mathbf{Y} \in \{1, \dots, q\}^{h \times w}$ 。低层特征保留较精细的边缘，高层特征能够结合更大的上下文；解码时既需要知道区域属于什么，也需要知道轮廓落在哪里。

U-Net 用从编码器到对应解码阶段的**跳跃连接**（skip connection）补充这些信息，即让较早的特征直接进入较后的计算。它在同一尺度上沿通道轴拼接编码特征与上采样后的解码特征，再用卷积融合。这里的跳跃连接与 ResNet 的残差相加不同：前者保留两组独立通道，后者在对应坐标上求和。原始 U-Net 采用不填充卷积，需要裁剪编码特征再拼接；本节教学版本采用保持尺寸的卷积，简化空间对齐²⁴。

图 9.23 将一个三尺度例子的编码、解码主路径排成一行，上方保留同尺度的跳跃连接。64×64 输入在最高分辨率产生 32 个通道，下采样到 32×32 后产生 64 个通道，再到 16×16 产生 128 个通道。解码器把低分辨率特征上采样，并与相同网格的编码特征拼接；卷积再将拼接结果整理为该尺度的输出通道。最终用 1×1 卷积将每个位置的 32 维特征映射为 q 个类别得分。

上采样（upsampling）是增加网格分辨率的操作。可以先用最近邻或双线性插值生成更密的网格，再用普通卷积处理；也可以用转置卷积共同完成位置扩展与可学习变换。插值方式、目标尺寸和坐标对齐约定都要固定。输入高、宽若不能被总下采样倍数整除，应在进入网络前填充、在输出后裁剪，或显式按目标尺寸上采样，不能只按通道数判断能否拼接。

训练时，每张图像提供像素标签，网络按式(9.49)计算损失，再联合更新编码器、解码器和输出头。未标注位置通过掩码排除；若少数类别被大量背景像素淹没，可以在明确权重和归一化后使用加权损失。推理时不需要标签，在各位置取最大得分类别，得到与目标网格对齐的分割图。像素准

²⁴ O. Ronneberger, P. Fischer, T. Brox, *U-Net: Convolutional Networks for Biomedical Image Segmentation* In Medical Image Computing and Computer-Assisted Intervention, 2015, pp. 234–241




图 9.23 用于分割或着色的三尺度编码器—解码器。长方体表示特征张量，标签给出空间尺寸和通道数。每级解码先上采样到下一尺度，再由圆形 + 沿通道拼接同尺度的编码特征，随后卷积融合；上方旁路均接入拼接节点。图中上采样保持通道数，因此两次拼接分别得到 $128 + 64 = 192$ 和 $64 + 32 = 96$ 个通道，卷积后变为 64 和 32 个。输出头产生 q 个类别得分或两个颜色通道；采用 same 卷积，省略原始 U-Net 的裁剪。

准确率可能主要反映背景，因此评价还需按任务检查区域重叠和边界质量，具体指标在图像处理部分展开。

跨尺度连接补回的是编码器仍保存的细节，不能创造输入中没有的信息。如果编码器已把小目标消去，或训练标签的边界本身不可靠，增加解码层数也不会自动修复。选择分辨率、下采样深度和损失时，需要保持目标尺度、标注质量与结构之间的配合。

9.7.2 图像生成

灰度图只提供亮暗信息，同样亮度的区域可以对应不同颜色。灰度图着色因此是一个**条件图像生成**（conditional image generation）问题：给定输入图像，生成与它相容的颜色图像。本节沿用编码器—解码器，展示如何形成空间输出；多个合理颜色之间的不确定性还需要由输出和目标来表达。

采用 Lab 颜色表示时，一个通道描述亮度，另外两个通道描述颜色差异。把亮度按固定规则归一化为输入 $\mathbf{X} \in \mathbb{R}^{h \times w \times 1}$ ，将训练彩色图的两个颜色通道按预定尺度变为目标 $\mathbf{C} \in \mathbb{R}^{h \times w \times 2}$ 。编码器读取亮度中的边缘、纹理和上下文，解码器恢复颜色的空间分布，最后用 1×1 卷积输出两个通道。若目标被缩放到 $[-1, 1]$ ，可以在输出使用 Tanh；采用线性输出时，则需在转换与显示环节处理范围。归一化常数、反归一化和颜色空间转换必须一致，转成 RGB 后还要处理显示色域。

最直接的教学模型产生确定的颜色估计 $\hat{\mathbf{C}} = \mathbf{f}_{\theta}(\mathbf{X})$ ，用像素平方损失训

练:

$$\ell_{\text{col}} = \frac{1}{hw} \sum_{i=0}^{h-1} \sum_{j=0}^{w-1} \|\hat{\mathbf{c}}_{i,j,:} - \mathbf{c}_{i,j,:}\|_2^2. \quad (9.73)$$

分割与着色的主体可以采用相同的空间结构，但分割在每个位置输出类别概率，着色在这里输出两个连续值。使用时，将预测颜色反归一化，与输入亮度组合，再转换成彩色图像；模型不应无意中改变输入与输出的空间对齐。

平方损失还有一个与任务有关的限制。在颜色具有有限二阶矩且预测函数可自由选择时，条件平方损失的最优预测是 $\mathbb{E}[\mathbf{C} | \mathbf{X}]$ 。若同一个灰度输入可能对应多种相距较远的颜色，平均值未必是一种合理着色；例如红与绿的平均可能降低饱和度。Zhang 等将颜色空间离散成候选颜色，预测每个位置的颜色分布，用分类目标保留这种多解性，并讨论了平方损失的平均效应²⁵。

若把输出头改为 q_{col} 个颜色得分，就可以逐位置归一化为候选颜色概率，再按约定选择、平均或采样得到颜色。即使每个位置都有概率分布，也不自动获得整张图像在空间上的一致性。若希望对同一输入生成多个整体协调的结果，还需要引入随机变量并设计相应的分布学习目标。这里的确定性编码器—解码器说明了卷积如何连接亮度、上下文和颜色输出，不把单次回归预测当作完整的条件生成分布。

²⁵ R. Zhang, P. Isola, A. A. Efros, *Colorful Image Colorization In Proceedings of the European Conference on Computer Vision*, 2016, pp. 649–666

9.8 本章小结

卷积网络对开篇问题给出了两项具体回答：局部连接把每次计算限定在邻域内，参数共享让同一组规则在不同位置重复使用。多通道组织保存不同的局部特征，非线性与层次组合使这些特征逐步参与更大范围的判断。网络是否保留空间轴、怎样处理边界和下采样，则决定了这种表示能否用于整体分类或逐位置输出。

计算算法规定如何得到卷积结果，工程实现规定怎样组织存储、访存与并行执行。直接计算、矩阵化和变换方法各有运算与数值代价，分块、展开和融合则改变数据复用与读写；二者需要结合层形状和平台选择。

数学卷积包含核翻转，网络常用互相关；填充、跨步、空洞和转置分别改变边界、窗口移动、核内采样与线性映射方向。明确这些约定，才能一致地计算输出形状、实现运算和推导梯度。参数共享使核梯度沿位置累积，窗口重叠使输入梯度累积；转置卷积在反向传播中出现，是因为链式法则需要转置算子，而非因为它能够逆转前向信息损失。

跨层相加、门控与拼接改变了深层计算中的信息和梯度路径，也带来不同的通道规模与成本。它们帮助组织可训练的网络，却没有单独保证泛化。预测可靠性仍取决于结构是否保留目标所需信息、样本是否提供足够独立

证据、参数与传播尺度是否受控，以及算法能否得到合适的解。分割与着色共同显示了这种配合：编码器构造上下文，解码器形成空间输出，跳跃连接保留细节，而输出头和损失决定最终预测究竟表示类别、连续值还是不确定性。

循环神经网络

判断“这部电影并不精彩”的情感时，“精彩”前面的否定不能丢掉；根据设备读数预测下一时刻的温度时，当前数值也不能完全代替此前的变化过程。第 8 章说明了怎样把一个固定维度的输入变成预测，第 9 章则利用局部邻域和参数共享处理规则网格。本章面对的问题是：输入陆续到达、序列长度可变时，网络怎样把历史中有用的信息带到当前，又怎样从当前的错误学会调整此前的处理？

这包含三个相互制约的要求。状态必须容纳预测所需的历史，训练必须把损失传到相关参数，计算还要适应整段训练或逐步预测。普通循环网络建立共同基础；储备池、控制门、注意力和结构化状态更新分别改变状态的构造、选择、读取或计算方式。拓扑与深度扩展改变信息的可见范围，理论分析检查优化和泛化所需的条件，应用部分把模型接回完整的数据与预测过程。

10.1 循环神经网络概述

一种直接做法是把最近若干个观测拼成向量，交给前馈网络。这个窗口可以包含顺序，但窗口以外的信息不再参与预测；改变窗口长度还可能改变输入层的参数规模。时间卷积通过共享卷积核改善了这一点，但固定层数和核尺寸仍对应有有限的感受野。若希望同一套计算持续处理新输入，就需要一个随着输入更新、能够传递历史影响的内部变量。

这个变量称为**隐状态** (hidden state)：它是网络根据已读输入形成的内部表示，不是训练样本直接提供的标签。设输入序列为 $\mathbf{x}_1, \dots, \mathbf{x}_T$ ，其中 $\mathbf{x}_t \in \mathbb{R}^d$ ，长度 T 可以随样本改变。用 $\mathbf{h}^{(t)} \in \mathbb{R}^m$ 表示读完第 t 个输入后的状态，**循环神经网络** (recurrent neural network, RNN) 通过状态反馈，把前一步的内部表示用于下一步计算：

$$\mathbf{h}^{(t)} = F_{\theta}(\mathbf{h}^{(t-1)}, \mathbf{x}_t), \quad t = 1, \dots, T. \quad (10.1)$$

这里 F_{θ} 是具有参数 θ 的更新函数， $\mathbf{h}^{(0)}$ 是初始状态。下标 t 标识序列中的

输入，上标 (t) 标识状态更新的步数；它们在本章按同一步对齐。状态可以记录否定词、近期趋势或别的任务特征，但式(10.1)本身没有保证它保存了全部历史。

同一组 θ 在不同时间步复用，称为时间方向的**参数共享** (parameter sharing)。因此，延长序列会增加更新次数，却不必增加循环单元的参数量。**时间展开** (unrolling through time) 则把这些更新依次画成计算图：第 t 步读取已经得到的第 $t-1$ 步状态，展开图沿时间前进，没有要求同一步无限循环求值。图 10.1 将状态反馈和展开图对应起来；展开后的深度随 T 增长，也是长序列训练困难的来源。




图 10.1 状态递推的紧凑表示与时间展开。蓝色节点提供当前输入，红色方框计算隐状态，黄色节点读出预测。展开图中的 F_θ 是同一个更新函数的多次调用，参数共享而状态值不同。红色虚线示意较晚损失沿状态依赖回传梯度；图中只画三个更新步。

循环网络的发展围绕两件事展开：怎样形成历史表示，以及怎样学到有用的状态更新。Elman 在 1990 年的简单循环网络中，把前一步隐藏活动送回下一步，展示了这种上下文表示如何随序列任务形成。反馈在展开后成为一条时间链，同一参数因而可以作用于不同位置¹。

能够表达历史，并不等于容易学到远距离依赖。Bengio、Simard 和 Frasconi 在 1994 年分析了梯度学习与长期保留之间的困难：误差经多步状态变换回传时，影响可能迅速衰减或放大。这把研究重点从“网络是否含有反馈”推进到“反馈路径怎样传递信息与梯度”²。

1997 年的 LSTM 为持续记忆安排了单独的加性路径，后来加入的遗忘门使网络能够清除不再相关的内容。它改变的是状态内部的信息通路，而不是放弃任务驱动的循环参数学习。2001 年的 ESN 和 2002 年的 LSM 则采用另一种分工：先构造通常固定的动态储备池，再学习任务读出。前一条路线让网络学习如何保存，后一条路线先提供历史特征；各自的原始工作和结构差别在第 10.4 节与第 10.3 节展开。

¹ J. L. Elman, *Finding Structure in Time* In *Cognitive Science*, 1990, vol. 14, no. 2, pp. 179–211

² Y. Bengio, P. Simard, P. Frasconi, *Learning Long-Term Dependencies with Gradient Descent Is Difficult* In *IEEE Transactions on Neural Networks*, 1994, vol. 5, no. 2, pp. 157–166

序列任务也推动了输出组织的变化。2014 年，编码器—解码器使用一套循环网络读取源序列，另一套网络生成目标序列；Sutskever 等用多层 LSTM 展示了这种端到端学习方式³。同年的 GRU 用较少的门组织状态更新。随后，Bahdanau 与 Luong 等的循环注意力模型让每个生成步骤重新读取编码器各位置的表示，减轻全部输入只能挤入同一末状态的限制。控制门改变保存方式，注意力改变读取方式，二者可以同时使用。

³ I. Sutskever, O. Vinyals, Q. V. Le, *Sequence to Sequence Learning with Neural Networks* In *Advances in Neural Information Processing Systems*, 2014

较新的状态空间路线还关心整段序列的计算组织。2020 年的 HiPPO 把历史记忆写成在线投影问题；S4 利用相应结构矩阵和快速核生成，在递推与卷积之间切换。2023 年的 Mamba 把部分系数改为由输入产生，再通过选择性扫描计算；同年的 RWKV 以内容权重、时间衰减与定长累积量组织历史。第 10.6 节将分别说明这些设计的原始形式。它们没有取消状态递推，而是把状态的构造、访问与计算作为不同问题来处理。

本章按历史经由隐状态传递这一共同机制组织内容：链式循环、树递归、储备池以及基于隐状态递推的状态空间网络都在这里讨论。具体文献可能把状态空间网络单列为一类；这种归并不意味着各模型具有相同的更新函数或训练算法。时间步也不必是物理时间，可以表示词的位置、扫描位置或有向结构中的计算次序。

10.2 基础循环神经网络

要理解各种扩展，先把状态更新、任务输出和梯度计算分清。循环单元决定历史如何压缩，读出方式决定在什么位置预测，损失决定哪些更新受到监督。改变其中一项，并不必然要求另外两项同时改变。

10.2.1 网络结构

普通 RNN 把前一步状态和当前输入映射到同一个隐藏空间，再逐坐标使用非线性函数。采用列向量约定，令

$$\begin{aligned} \mathbf{z}^{(t)} &= \mathbf{U}\mathbf{x}_t + \mathbf{W}\mathbf{h}^{(t-1)} + \mathbf{b}, \\ \mathbf{h}^{(t)} &= \tanh(\mathbf{z}^{(t)}), \\ \mathbf{a}^{(t)} &= \mathbf{V}\mathbf{h}^{(t)} + \mathbf{c}, \quad \hat{\mathbf{y}}_t = g(\mathbf{a}^{(t)}). \end{aligned} \quad (10.2)$$

其中 $\mathbf{U} \in \mathbb{R}^{m \times d}$ 是输入映射， $\mathbf{W} \in \mathbb{R}^{m \times m}$ 是状态转移矩阵， $\mathbf{b} \in \mathbb{R}^m$ 是隐藏偏置； $\mathbf{V} \in \mathbb{R}^{q \times m}$ 和 $\mathbf{c} \in \mathbb{R}^q$ 产生 q 维输出得分。 g 按任务选择恒等映射、Sigmoid 或 Softmax，输出与损失的配合沿用第 8.1.3 节。Tanh 可替换为其他激活，但梯度和状态范围会随之改变。

这个单元及读出共有 $md + m^2 + m + qm + q$ 个参数，忽略逐坐标运算后，一步稠密计算的乘加量为 $O(md + m^2 + qm)$ 。长度为 T 的前向计算重复 T 次。固定宽度时，逐步预测只需维护当前状态；完整反向传播通常

还要保存沿途的激活，不能把预测的状态存储量直接当成训练的全部存储量。

10.2.1.1 序列到分类

如果一整段评论只对应一个情感标签，网络应在读完有效输入后输出一次。**序列到分类**（sequence classification）把长度可变的输入变成一个类别预测。最直接的读出使用末状态：

$$\mathbf{p} = \text{softmax}(\mathbf{V}\mathbf{h}^{(T)} + \mathbf{c}), \quad \ell = -\log p_y, \quad (10.3)$$

其中类别数为 K 、 $q = K$ 、真实标签为 $y \in \{1, \dots, K\}$ 。末状态必须把与类别有关的信息带到结尾，所以较早出现的证据也要经过后续更新。

另一种读出对状态聚合，例如用 $\bar{\mathbf{h}} = T^{-1} \sum_{t=1}^T \mathbf{h}^{(t)}$ 替代末状态。这里聚合的是已含历史的状态，仍然可以体现顺序；但平均会稀释只出现在少数位置的证据。末状态、平均、最大池化和可学习聚合各自保留不同信息，应根据标签依赖的范围比较，而不是仅按实现是否方便选择。

图 10.2 显示了末状态分类的监督位置：只有读完有效序列后，分类头才形成整段预测。




图 10.2 序列到分类。三个输入依次更新同一循环单元，末状态产生类别概率 $\mathbf{p}$ 。蓝色表示输入，红色表示隐状态，黄色表示任务输出；图中只示意长度为 3 的序列。

10.2.1.2 同步序列到序列

若每个词都要预测一个标签，输入位置与输出位置对齐。**同步序列到序列**（aligned sequence-to-sequence）在每个有效位置读出：

$$\ell = \frac{1}{T} \sum_{t=1}^T \ell_t(\mathbf{g}(\mathbf{V}\mathbf{h}^{(t)} + \mathbf{c}), y_t). \quad (10.4)$$

单向状态 $\mathbf{h}^{(t)}$ 只读取 $\mathbf{x}_1, \dots, \mathbf{x}_t$ 。这适合实时预测，但不能利用尚未到达的词。若任务允许读取整段输入，可以使用第 10.7.1 节的双向结构补充后文信息。

时间预测也可以按位置组织，但要注明输出的时间含义。例如读入 $\mathbf{x}_t$ 后预测 $\mathbf{x}_{t+1}$ ，计算索引仍是 t ，目标却是下一步观测。对齐的是输入位置

与预测位置的组织方式，不是要求二者表示同一物理时刻。

图 10.3 在各位置设置读出；它与末状态分类共享同一种状态递推，但各位置都可以收到监督。




图 10.3 同步序列到序列。每个输入位置形成一个隐状态和相应预测。输入位置与预测位置对齐；若用于下一时刻预测，应另将目标移到后一时刻。图中单向状态只读取当前及此前输入。

10.2.1.3 异步序列到序列

把一段输入转换为另一段序列时，两者可能长度不同，也没有已知的逐位置对应。**编码器—解码器**（encoder-decoder）把读取输入和产生输出分成两套计算：编码器形成上下文，解码器以此为条件生成目标。设目标长度为 S ，目标符号来自大小为 K 的词表，约定词表包含起止符号 BOS 和 EOS。

符号本身不能直接参与向量运算，可以为每个符号保存一个 d_e 维的可学习向量，并将它们排成嵌入矩阵 $\mathbf{E} \in \mathbb{R}^{d_e \times K}$ 。若 y 是符号的词表索引，**符号嵌入**（symbol embedding）就是查表取出的那一列，即 $\mathbf{e}(y) = \mathbf{E}_{:,y}$ ；索引只用于选列，其数值大小不表示符号间的距离。用 $\mathbf{s}^{(j)}$ 表示解码状态，基本形式为

$$\begin{aligned} \mathbf{c}_{\text{enc}} &= \mathbf{h}^{(T)}, & \mathbf{s}^{(0)} &= \psi(\mathbf{c}_{\text{enc}}), \\ \mathbf{s}^{(j)} &= F_{\text{dec}}(\mathbf{s}^{(j-1)}, \mathbf{e}(y_{j-1}), \mathbf{c}_{\text{enc}}), \\ \mathbf{p}^{(j)} &= \text{softmax}(\mathbf{V}_{\text{dec}}\mathbf{s}^{(j)} + \mathbf{b}_{\text{dec}}). \end{aligned} \quad (10.5)$$

ψ 将编码状态映射到解码状态空间，编码器与解码器可以使用不同参数和宽度。起始符号 $y_0 = \text{BOS}$ 为第一步提供输入，终止符号 EOS 表示生成结束；它们也有各自的嵌入列。下文把 $y_S = \text{EOS}$ 计入目标序列。使用真实前缀训练时， y_{j-1} 来自目标序列；生成时，它来自上一步概率分布中选出或采样的符号。两种情况都先查表得到 $\mathbf{e}(y_{j-1})$ 再输入解码器，并非把整组类别概率当作这个嵌入；嵌入矩阵与其他网络参数一起通过训练更新。




图 10.4 异步序列到序列。编码器读取三个源输入，解码器在初态 $s^{(0)}$ 之后生成三个目标。BOS 启动生成，此前目标经嵌入反馈到下一步，黄色虚线示意这一反馈。训练可使用真实目标，预测使用已生成目标；图中省略每步重复读取的固定上下文。

目标序列的条件概率按生成次序分解：

$$p_{\theta}(y_{1:S} | \mathbf{x}_{1:T}) = \prod_{j=1}^S p_{\theta}(y_j | y_{0:j-1}, \mathbf{x}_{1:T}), \quad (10.6)$$

$$\ell = - \sum_{j=1}^S \log p_{y_j}^{(j)}.$$

这里 $y_{1:S}$ 、 $\mathbf{x}_{1:T}$ 简记相应序列。条件中保留了此前目标，所以概率分解没有假设目标位置互相独立。对损失求和或按 S 平均会改变不同长度样本的权重，训练时应明确采用哪一种。

图 10.4 将读取源序列与生成目标分开。两侧各画三个有效位置以便比较，并不要求实际源序列与目标序列等长。

10.2.2 参数学习

每次更新都使用相同参数，训练必须把参数在不同时间步的影响加起来。输入和输出映射可沿用第 8.2.1 节的尺度原则。循环矩阵会被重复使用，除了单步方差，还要关注多步乘积：正交初始化可令初始线性变换保持欧氏范数，但激活的导数仍会改变实际传播；它不是长序列可训练性的保证。

独立序列通常从零状态或同一个可学习的初始状态开始。若初始状态可学习，其梯度也由反向传播得到。连续数据流可以延续状态，但批次中的每一行必须继续对应同一条数据流；换成无关样本时需要重置。把上一个测试样本的状态带入下一个独立样本，会改变预测条件。

10.2.2.1 随时间反向传播与共享梯度

把状态递推展开后,就能使用前馈网络的链式法则。**随时间反向传播**(back-propagation through time, BPTT) 沿时间展开图从后向前计算导数。以下以式(10.2)为对象, 令单序列目标为 $L = \sum_{t=1}^T \ell_t$; 没有监督的位置取 $\ell_t = 0$ 。记 $\mathbf{g}^{(t)} = \partial \ell_t / \partial \mathbf{a}^{(t)}$, 总损失对状态的梯度为 $\mathbf{r}^{(t)}$, 对预激活的梯度为 $\delta^{(t)}$, 则

$$\begin{aligned} \mathbf{r}^{(t)} &= \mathbf{V}^\top \mathbf{g}^{(t)} + \mathbf{W}^\top \delta^{(t+1)}, \\ \delta^{(t)} &= \mathbf{r}^{(t)} \odot (\mathbf{1} - \mathbf{h}^{(t)} \odot \mathbf{h}^{(t)}), \quad \delta^{(T+1)} = \mathbf{0}. \end{aligned} \quad (10.7)$$

$\odot$ 表示逐元素乘法。第一项来自当前读出, 第二项来自后续状态; 即使当前没有标签, 后续损失仍可通过第二项监督这一步。若只在末状态分类, $t < T$ 的 $\mathbf{g}^{(t)}$ 均为零, 但相应 $\delta^{(t)}$ 未必为零。

每次调用都对共享参数产生一个局部贡献。求这一局部贡献时, 将该步读入的上一状态视为独立输入; 跨步依赖已经由 $\delta^{(t)}$ 汇总, 不能再对上一状态重复求导。把所有调用的贡献累积起来, 得到

$$\begin{aligned} \nabla_{\mathbf{U}} L &= \sum_{t=1}^T \delta^{(t)} \mathbf{x}_t^\top, & \nabla_{\mathbf{W}} L &= \sum_{t=1}^T \delta^{(t)} (\mathbf{h}^{(t-1)})^\top, \\ \nabla_{\mathbf{b}} L &= \sum_{t=1}^T \delta^{(t)}, & \nabla_{\mathbf{V}} L &= \sum_{t=1}^T \mathbf{g}^{(t)} (\mathbf{h}^{(t)})^\top, \\ \nabla_{\mathbf{c}} L &= \sum_{t=1}^T \mathbf{g}^{(t)}, & \nabla_{\mathbf{h}^{(0)}} L &= \mathbf{W}^\top \delta^{(1)}. \end{aligned} \quad (10.8)$$

这些梯度的形状与相应参数一致。自动微分会完成求和, 但理解求和的来源, 才能区分“同一参数多次使用”和“每步拥有一套新参数”。若目标按时间平均, 相应梯度还需除以有效长度。




图 10.5 两时间步 BPTT 的显式展开。蓝色实线是共享 $\mathbf{W}_{hh}$ 的前向调用, 红色虚线从 ℓ_2 与 ℓ_1 回传并在 δ_1 处汇合; 同一循环矩阵的梯度等于两个调用位置的外积贡献之和。底部指出长序列中状态 Jacobian 连乘是梯度消失或爆炸的直接来源。

示例 10.1 两步递推中的梯度累积 为单独观察共享参数, 暂把 Tanh 换成恒等映射, 使用标量更新 $h^{(t)} = wh^{(t-1)} + x_t$; w 是矩阵 $\mathbf{W}$ 的一维情形。取固定初始状态 $h^{(0)} = 1$ 、 $x_1 = 1$ 、 $x_2 = 0$ 、 $w = 1/2$, 只在末步计算损失 $L = (h^{(2)})^2/2$ 。两次前向调用为

$$\begin{aligned} h^{(1)} &= \frac{1}{2} \times 1 + 1 = \frac{3}{2}, \\ h^{(2)} &= \frac{1}{2} \times \frac{3}{2} + 0 = \frac{3}{4}. \end{aligned}$$

反向从 $r^{(2)} = h^{(2)} = 3/4$ 开始, 再沿第二步的状态依赖得到 $r^{(1)} = wr^{(2)} = 3/8$ 。本例激活导数为 1, 故 $\delta^{(t)} = r^{(t)}$ 。第二次调用对 w 的局部导数是 $h^{(1)}$, 第一次是 $h^{(0)}$, 所以共享参数收到两项贡献:

$$\begin{aligned} \frac{dL}{dw} &= r^{(1)}h^{(0)} + r^{(2)}h^{(1)} \\ &= \frac{3}{8} \times 1 + \frac{3}{4} \times \frac{3}{2} = \frac{3}{8} + \frac{9}{8} = \frac{3}{2}. \end{aligned}$$

第一项对应依赖路径 $w \rightarrow h^{(1)} \rightarrow h^{(2)} \rightarrow L$, 第二项对应 $w \rightarrow h^{(2)} \rightarrow L$; 梯度沿这些依赖逆向回传。两条路径的贡献最终相加, 更新的仍是同一个 w 。直接展开 $h^{(2)} = w(w+1) = w^2 + w$, 也有 $dL/dw = (w^2 + w)(2w + 1) = 3/2$, 可与反向递推核对。

若改取 $h^{(0)} = 0$, 第一步对 w 的贡献为零, 因为 w 乘到零初态; 这不表示第一步未参与共享计算。若将本例的 $h^{(0)} = 1$ 改为可学习初态, 它收到的梯度为 $wr^{(1)} = 3/16$, 与 w 的梯度分开更新。

10.2.2.2 截断、裁剪与状态管理

长序列的完整展开会占用大量训练存储。**截断随时间反向传播** (truncated BPTT) 把数据流分成有限长度的片段, 在片段边界保留状态数值, 却切断对更早计算的求导依赖。这样, 当前预测仍可使用此前状态, 但当前损失不能跨过边界调整形成该状态的早期计算。截断减小了反向图, 并没有把前向记忆自动限制为片段长度; 它一般给出完整梯度的有偏近似。

梯度过大时, 可以在优化器更新之前使用**梯度裁剪** (gradient clipping), 把梯度范数限制在阈值内。将全部参数梯度拼成 $\mathbf{g}$, 阈值为 $\tau > 0$, 全局范数裁剪写为

$$\tilde{\mathbf{g}} = \begin{cases} \mathbf{g}, & \|\mathbf{g}\|_2 \leq \tau, \\ \tau \mathbf{g} / \|\mathbf{g}\|_2, & \|\mathbf{g}\|_2 > \tau. \end{cases} \quad (10.9)$$

它保持非零梯度的方向并限制步长尺度, 有助于避免一次异常梯度导致大幅更新, 但不会恢复已经消失的梯度, 也没有改变前向状态的稳定性。Pascanu 等从状态雅可比乘积分析这两类梯度问题, 并研究了裁剪的作

用⁴。

可变长度批次常用填充补齐。**掩码** (mask) 标记哪些位置是真实数据, 使填充位置不参与损失或状态聚合。末状态读出应取每个样本的有效末位置; 若继续在填充上更新, 状态可能改变。分类时的平均聚合也应除以有效长度, 而不是批次中的最大长度。

⁴ R. Pascanu, T. Mikolov, Y. Bengio, *On the Difficulty of Training Recurrent Neural Networks* In Proceedings of the 30th International Conference on Machine Learning, 2013, pp. 1310–1318

10.2.2.3 教师强制与实际预测

式(10.6)计算的是给定真实前缀的条件概率。训练时把真实 y_{j-1} 作为第 j 步输入, 称为**教师强制** (teacher forcing): 用正确前缀让模型学习下一符号的条件分布。预测时没有真实目标, 只能反馈此前生成的符号。此前生成错误会改变后续状态, 训练与预测遇到的前缀分布由此可能不同。

教师强制仍是所定义条件似然的正确计算方式, 前缀分布差异不能自动推出训练目标错误。混合真实符号与模型生成符号会改变训练过程, 需要重新说明其目标。无论使用何种训练输入, 评估生成质量都应按真实预测过程逐步运行。贪心解码每步选择概率最大的符号; 束搜索保留多个候选前缀, 但并不保证找到全局概率最大的完整序列。

10.2.3 长期依赖问题及解决思路

较早的输入能否影响很晚的输出, 取决于这种影响经过多次更新后还剩多少。**长期依赖** (long-term dependency) 指当前任务需要利用相距很多步的信息; 相隔多少步算长, 要相对于任务和模型的有效记忆尺度判断。

固定输入序列, 记一步更新的状态**雅可比矩阵** (Jacobian matrix) 为 $\mathbf{J}^{(t)} = \partial \mathbf{h}^{(t)} / \partial \mathbf{h}^{(t-1)}$, 它描述前一步状态的小变化如何影响后一步。链式法则给出

$$\frac{\partial \mathbf{h}^{(t)}}{\partial \mathbf{h}^{(s)}} = \mathbf{J}^{(t)} \mathbf{J}^{(t-1)} \dots \mathbf{J}^{(s+1)}, \quad t > s. \quad (10.10)$$

前向的状态敏感度使用这个乘积, 反向的损失梯度使用其转置。普通 Tanh 单元中, $\mathbf{J}^{(t)} = \mathbf{D}^{(t)} \mathbf{W}$, $\mathbf{D}^{(t)}$ 的对角元素为 $1 - (h_i^{(t)})^2$ 。因此, 仅控制 $\mathbf{W}$ 的特征值还不足以描述全部多步传播。

若所有相关步都有 $\|\mathbf{J}^{(t)}\|_2 \leq r < 1$, 则乘积范数不超过 r^{t-s} , 早期扰动与沿这条路径回传的梯度都受到指数衰减的上界。**梯度消失** (vanishing gradients) 使早期参数难以收到有效更新。若某些方向在多步乘积中持续放大, 则可能出现**梯度爆炸** (exploding gradients)。单步范数大于 1 并不保证每个方向或每条输入轨迹都爆炸; 矩阵方向、激活饱和和输入共同决定实际乘积。

示例 10.2 传播距离与状态保留 对线性标量递推 $h^{(t)} = ah^{(t-1)} + x_t$, 若 $x_1 = 1$ 、后续输入为零且 $h^{(0)} = 0$, 则 $h^{(T)} = a^{T-1}$, 跨步敏感度也为 a^{T-1} 。取 $T = 101$, $a = 0.9$ 时为约 2.66×10^{-5} , $a = 1.1$ 时为约 1.38×10^4 。取 $a = 1$ 可以保留这个单一信号, 却会把多个输入不断相加; 保留信息与区分不同历史仍是两个要求。

要比较解决思路, 可以把式(10.10)中的两个因素分开: 传播路径包含多少次变换, 每次变换又怎样放大或衰减。对一条含 ν 次状态变换的路径, 若各步范数不超过 r , 则

$$\|J_\nu \cdots J_1\|_2 \leq \prod_{k=1}^{\nu} \|J_k\|_2 \leq r^\nu. \quad (10.11)$$

r 控制逐步变化的尺度, ν 控制这种变化重复多少次。这个上界不是每个方向的实际传播系数, 但能帮助区分下面几类设计。

10.2.3.1 参数约束: 控制逐步放大与衰减

若传播方向的增益长期大于 1, 限制状态变换的范数可以减小指数放大; 若增益长期小于 1, 只把范数压得更小反而会加重消失。保存长期影响需要相关方向的传播系数接近 1, 同时限制异常放大的方向。因此, “降低底数” 主要对应抑制爆炸, 缓解消失则要控制衰减, 使需要保留的方向不被过度压缩。

更强的条件同时约束最大和最小奇异值。若各步状态雅可比的奇异值均在 $[q, r]$ 内, $q > 0$, 对任意末端梯度 $\mathbf{v}$ 有

$$q^\nu \|\mathbf{v}\|_2 \leq \|(J_\nu \cdots J_1)^\top \mathbf{v}\|_2 \leq r^\nu \|\mathbf{v}\|_2. \quad (10.12)$$

使 q 与 r 都接近 1, 才同时抑制过快衰减与过快放大。普通 Tanh 单元的 $J^{(t)} = D^{(t)}W$ 还包含激活导数: 即使约束 $W^\top W = I$, 饱和的 Tanh 仍可使 $D^{(t)}$ 接近零。正交或酉矩阵约束保护的是线性部分, 必须配合激活、输入尺度和完整雅可比分析⁵。

固定储备池是对可训练参数施加更强约束的一种做法。把循环动态参数 θ_{res} 固定为 θ_0 , 相当于将其可行集合限制为单点 $\{\theta_0\}$, 任务训练只优化读出参数。储备池构造还常限制循环矩阵的尺度、连接和泄漏率, 以安排状态的稳定性和记忆时间尺度。

但固定参数与控制雅可比是两件事。冻结一个衰减过快的动态, 不会让已经丢失的信息重新出现; 冻结一个不稳定的动态, 也不会自动使它稳定。固定储备池的另一项作用, 是训练时不再需要把末端错误沿长时间链传回循环参数, 读出只需利用已经生成的状态特征。它绕开了这部分循环

⁵ M. Arjovsky, A. Shah, Y. Bengio, *Unitary Evolution Recurrent Neural Networks* In Proceedings of the 33rd International Conference on Machine Learning, 2016, pp. 1120–1128

参数的长距离信用分配，而不是消除了前向状态中的长期依赖问题。

10.2.3.2 跨时间跳跃：减少一条路径的变换次数

另一种做法增加从较早状态直接到较晚状态的边，例如

$$\mathbf{h}^{(t)} = F_{\theta}(\mathbf{h}^{(t-1)}, \mathbf{x}_t) + \mathbf{S}\mathbf{h}^{(t-k)}, \quad t \geq k, \quad (10.13)$$

其中 k 是跳跃间隔， $\mathbf{S} \in \mathbb{R}^{m \times m}$ 是直达映射，边界状态另行初始化。从 $t-k$ 到 t 的直接路径只经过 $\mathbf{S}$ 。跨越距离 pk 时，沿连续跳跃边的一条路径经过 p 次变换；在 $\|\mathbf{S}\|_2 \leq r$ 下，该路径的范数上界为 r^p ，普通逐步路径则可能含 pk 次变换。

在标量教学例子中，同样以 0.9 为路径系数，跨 100 步的逐步路径为 $0.9^{100} \approx 2.66 \times 10^{-5}$ ，每 10 步跳一次的路径为 $0.9^{10} \approx 0.349$ 。这是新增路径的比较；完整梯度还要对所有路径的贡献求和，不能把整个网络的总导数一概改写成 r^v/k 。跳跃也需要保存相应旧状态，并可能跳过任务所需的细粒度处理。

跨层残差减少层方向的传播障碍，跨时间跳跃改变时间方向的依赖，二者不能混为一谈。即使某条直达路径系数为 1，其他分支和多路径求和仍可能放大梯度，读出也未必能从混合状态中取出目标信息。

10.2.3.3 控制门：让保留率随内容改变

固定约束对所有输入使用同一规则，任务却可能只需保存某些内容。控制门把保留系数变成输入相关量。以 LSTM 的直接记忆路径为例，暂固定门的数值后，从 s 到 t 的逐坐标系数为 $\prod_{u=s+1}^t f_i^{(u)}$ 。需要保存时令相应遗忘门接近 1，需要覆盖时降低它；输入门再调节新内容写入。门控主要改变逐步保留率与信息通路，通常没有减少时间步数。

门本身也依赖状态，完整雅可比还包含门与候选变化的路径。能建立接近恒等的记忆通路，为训练提供了选择，任务损失仍需学到何时使用它。第 10.4.1 节和第 10.4.2 节将把这些路径写成具体单元。

这几类方式可以组合：固定储备池也能加入跳跃连接，门控网络也能约束部分矩阵。比较时应分别检查传播路径、逐步增益、可训练参数范围，以及状态是否保留了读出所需的信息。

10.3 基于储备池的循环神经网络

如果难点在于学习复杂的循环动态，可以把构造动态与学习任务输出分开。**储备池计算** (reservoir computing) 用一个通常固定的动态系统把输入历史转换成丰富状态，再学习从状态到目标的读出。这里的**读出** (readout)

是任务输出映射：它接收状态特征，计算回归值或类别概率。状态随输入改变，但产生状态的循环参数通常不按当前任务的梯度更新。图 10.6 展示了这一分工。




图 10.6 储备池计算的参数分工。输入进入固定的循环动态，多个内部单元共同形成随历史变化的状态，可训练读出将状态映射到目标。灰色连线表示固定连接，黄色箭头表示参与拟合的读出；内部连接只示意结构，不表示某个随机生成样本。ESN 使用连续值激活，LSM 可由脉冲活动及其滤波响应形成读出特征。

10.3.1 ESN

回声状态网络 (echo state network, ESN) 是一种以连续值循环状态提供历史特征的储备池模型，Jaeger 的技术报告建立了其基本框架⁶。下面采用无输出反馈的泄漏积分版本，避免把真实目标或读出结果再送入储备池。令泄漏率 $\alpha \in (0, 1]$ ，更新为

$$\begin{aligned}\tilde{\mathbf{h}}^{(t)} &= \tanh(\mathbf{W}_{\text{res}} \mathbf{h}^{(t-1)} + \mathbf{U}_{\text{res}} \mathbf{x}_t + \mathbf{b}_{\text{res}}), \\ \mathbf{h}^{(t)} &= (1 - \alpha) \mathbf{h}^{(t-1)} + \alpha \tilde{\mathbf{h}}^{(t)}.\end{aligned}\quad (10.14)$$

$\mathbf{W}_{\text{res}} \in \mathbb{R}^{m \times m}$ 、 $\mathbf{U}_{\text{res}} \in \mathbb{R}^{m \times d}$ 和偏置通常构造后固定。较小 α 使每次状态变化较慢，但实际记忆还取决于循环矩阵、输入尺度和非线性响应。稀疏连接、输入缩放、泄漏率和状态维度均是可由验证选择的配置。

训练时先运行储备池，收集特征 $\mathbf{z}_t = [1; \mathbf{x}_t; \mathbf{h}^{(t)}] \in \mathbb{R}^{1+d+m}$ ，分号表示向量拼接。初始若干步可能主要反映人为初态，常丢弃这段**洗出期** (washout)，即先让系统接受输入、再开始拟合读出。独立序列的洗出和重置规则需一致，不能直接删掉恰好含有分类证据的开头。

对连续值目标，将 N 个有效状态按行堆成 $\mathbf{Z} \in \mathbb{R}^{N \times (1+d+m)}$ ，相应目标堆成 $\mathbf{Y} \in \mathbb{R}^{N \times q}$ 。线性读出参数为 $\mathbf{R} \in \mathbb{R}^{(1+d+m) \times q}$ ，采用平方损失和岭惩罚时

$$\begin{aligned}\mathbf{R}^* &= \arg \min_{\mathbf{R}} \|\mathbf{Z}\mathbf{R} - \mathbf{Y}\|_{\text{F}}^2 + \lambda \|\mathbf{R}\|_{\text{F}}^2, \\ \mathbf{R}^* &= (\mathbf{Z}^{\text{T}} \mathbf{Z} + \lambda \mathbf{I})^{-1} \mathbf{Z}^{\text{T}} \mathbf{Y}, \quad \lambda > 0.\end{aligned}\quad (10.15)$$

这里 $\|\cdot\|_{\text{F}}$ 是 Frobenius 范数。公式惩罚了包括截距在内的全部系数；若不

⁶ H. Jaeger, *The “Echo State” Approach to Analysing and Training Recurrent Neural Networks*, GMD Report 148, German National Research Center for Information Technology, 2001

惩罚截距，应改用相应角惩罚矩阵并另查可逆性。实际求解线性方程而不必显式求逆。分类可以使用 Softmax 读出和交叉熵，但不再具有上述平方损失的解析解。

储备池需要对相同输入历史产生一致状态，而不是长期依赖任选的初态。**回声状态性质** (echo state property, ESP) 要求在约定的输入与状态范围内，相同持续输入驱动下，初始状态的影响最终消失。对式(10.14), Tanh 是 1-Lipschitz, 因而两个状态的距离满足

$$\|\mathbf{h}^{(t)} - \mathbf{h}_{\text{alt}}^{(t)}\|_2 \leq (1 - \alpha + \alpha \|\mathbf{W}_{\text{res}}\|_2) \|\mathbf{h}^{(t-1)} - \mathbf{h}_{\text{alt}}^{(t-1)}\|_2. \quad (10.16)$$

这里 $\mathbf{h}^{(t)}$ 与 $\mathbf{h}_{\text{alt}}^{(t)}$ 表示初态不同、输入相同的两条轨迹。 $\|\mathbf{W}_{\text{res}}\|_2 < 1$ 给出统一收缩的充分条件，但不是必要条件。实践中按谱半径缩放矩阵，不能把“谱半径小于 1”直接当成任意非线性储备池的充分保证；相关反例与更精确条件见 Yildiz 等的分析⁷。

初态影响消失也意味着一部分过去影响会衰减，适当的衰减使模型能适应新输入，过快衰减却可能丢掉任务证据。**记忆容量** (memory capacity) 的一种线性测量方法，是对独立同分布的零均值标量输入分别学习各延迟的线性重构，再累加平方相关系数。在状态为 m 维、读出仅使用状态且采用相应总体最小二乘定义的条件下，总线性记忆容量不超过 m ；这不是对任意非线性任务的准确率保证⁸。因此，读出易于训练与状态足够有用仍须分别检验。

10.3.2 LSM

输入也可能由带时间戳的事件构成，如传感器事件或神经脉冲。**液态状态机** (liquid state machine, LSM) 用动态储备池的瞬时响应表示输入历史，代表性实现是固定的脉冲神经元回路，再学习状态读出。其名称强调利用持续变化的内部活动，不要求系统每次都收敛到一个稳定状态⁹。

图 10.7 把输入到任务输出的过程分开。输入是事件时，可以直接接入脉冲回路；连续观测则需按约定编码为输入脉冲。编码规则决定观测幅度、变化或时间如何进入回路，不能把脉冲网络的输入理解成未经转换的任意实数序列。

回路中的状态比“这个时刻是否发出脉冲”更丰富。例如一个简化的漏积分发放单元可以写为

$$\tau_m \frac{dv_i(\tau)}{d\tau} = -(v_i(\tau) - v_{\text{rest}}) + I_i(\tau) + \sum_j w_{i,j} (\kappa_{\text{syn}} * s_j)(\tau), \quad (10.17)$$

其中 v_i 是膜电位， $\tau_m > 0$ 是泄漏时间常数， I_i 表示换算到同一电位尺度的外部驱动， $w_{i,j}$ 是固定连接权重， $\kappa_{\text{syn}} * s_j$ 是此前脉冲经过突触滤波后的

⁷ I. B. Yildiz, H. Jaeger, S. J. Kiebel, *Re-Visiting the Echo State Property In Neural Networks*, 2012, vol. 35, pp. 1–9

⁸ H. Jaeger, *Short Term Memory in Echo State Networks*, GMD Report 152, German National Research Center for Information Technology, 2001

⁹ W. Maass, T. Natschlager, H. Markram, *Real-Time Computing Without Stable States: A New Framework for Neural Computation Based on Perturbations In Neural Computation*, 2002, vol. 14, no. 11, pp. 2531–2560




图 10.7 LSM 的输入、动态与读出。输入编码驱动固定的循环脉冲储备池，回路活动形成脉冲列 $s_i(\tau)$ ；因果滤波将这些活动变成当前可读特征 $\mathbf{z}(\tau)$ ，任务读出再映射为预测。红色反馈表示回路动态，黄色表示特征到预测的映射。此处只训练任务读出，脉冲编码、回路参数与滤波核按约定固定。

作用。膜电位达到阈值时发出脉冲并重置；这里省略不应期等细节。持续的膜电位、突触响应和反馈活动共同承载输入历史，当前输入停止后，内部影响仍可能延续。

若第 i 个单元在时刻 $\tau_{i,k}$ 发出脉冲，其脉冲列为 $s_i(\tau) = \sum_k \delta(\tau - \tau_{i,k})$ ， δ 是 Dirac 脉冲。它不是某一时刻的普通有限函数值，而是用积分记录一次单位事件：与连续权重函数相乘后积分，就取出该函数在发放时刻的值。因而可以用因果滤波核 κ_i 形成特征：

$$z_i(\tau) = \int_{-\infty}^{\tau} \kappa_i(\tau - u) s_i(u) du, \quad \kappa_i(u) = e^{-u/\tau_i} \mathbf{1}_{\{u \geq 0\}}. \quad (10.18)$$

$\tau_i > 0$ 是特征衰减时间常数， $\mathbf{1}$ 是指示函数。采用事件发生后立即计入当前状态的约定，积分可以逐个发放时刻展开为

$$z_i(\tau) = \sum_{k: \tau_{i,k} \leq \tau} \exp\left(-\frac{\tau - \tau_{i,k}}{\tau_i}\right). \quad (10.19)$$

每次脉冲向 z_i 加入 1，此后按已经过去的时间衰减；未来事件不参与求和。脉冲编码的进一步说明见第 13.2.1 节。这一步是状态读取：把回路活动整理成有限维、可供后续计算的 $\mathbf{z}(\tau)$ 。它未必完整包含膜电位和全部突触变量，因而不能自动重构整个回路。

读出是从这些状态特征到任务预测的映射，作用相当于前馈网络的输出头。读取特征与产生任务答案是两步计算；一个常用读出为

$$\mathbf{a}(\tau) = \mathbf{V}\mathbf{z}(\tau) + \mathbf{b}, \quad \hat{\mathbf{y}}(\tau) = g(\mathbf{a}(\tau)), \quad (10.20)$$

其中 $\mathbf{z} \in \mathbb{R}^m$ 、 $\mathbf{V} \in \mathbb{R}^{q \times m}$ 。回归可取 g 为恒等映射，分类可取 Sigmoid 或 Softmax；训练样本提供目标，监督 $\mathbf{V}, \mathbf{b}$ 的学习。读出也可以是更复杂的

可训练网络，但如果两种输入历史产生相同的 $\mathbf{z}$ ，任何只读取 $\mathbf{z}$ 的确定性读出都无法区分它们。

示例 10.3 从脉冲活动到预测 假设两个单元均使用时间常数 2：第一个在时刻 1 和 3 发放，第二个只在时刻 2 发放。在时刻 4，特征为 $z_1 = e^{-3/2} + e^{-1/2} \approx 0.830$ 、 $z_2 = e^{-1} \approx 0.368$ 。若教学例子中的回归读出为 $\hat{y} = 2z_1 - z_2 - 0.5$ ，便得到约 0.791。脉冲与滤波决定特征，系数 (2, -1) 和偏置决定这些特征怎样形成任务答案；真实训练应由样本估计后者。

训练时先按实际顺序驱动回路，在约定时刻收集状态特征及对应目标，再拟合读出。平方损失的线性读出可沿用 ESN 的岭回归，分类读出则使用相应分类目标。独立事件序列需要重置或约定初态，同一连续流可以延续状态；采集特征时仍须遵守预测时的信息范围。

LSM 对长期依赖的帮助来自动态特征的时间范围：较慢的突触/滤波响应保留较久的影响，循环反馈还可延长或重组这种影响。过快的衰减会丢掉远期证据，过强反馈可能使无关活动持续，多个历史也可能被压成相同特征。固定回路减少了训练循环参数的困难，但读出能否利用长期历史，取决于特征是否仍可区分任务所需的历史。

ESN 主要以连续值激活表示状态，LSM 利用脉冲时刻及其动态响应。事件稀疏时可采用事件驱动计算，数字仿真的更新、通信和读出成本仍需计入。脉冲编码、膜电位模型与可塑性学习在后续脉冲神经网络章展开，这里把动态历史表示与监督读出的分工说清。

10.4 基于控制门的循环神经网络

固定动态难以针对任务选择性地保留信息，普通 RNN 又把已有状态和新输入混合后整体变换。**控制门** (gate) 是由输入和状态计算的一组系数，用逐元素乘法调节哪些信息保留、写入或输出。Sigmoid 将系数限制到 (0, 1)，使门可以连续学习。门不是人工提供的开关标签，它们的参数由最终任务损失监督。

10.4.1 LSTM

长短期记忆 (long short-term memory, LSTM) 把持续保存的记忆和对外输出的隐藏表示分开，通过门调节二者。原始 LSTM 发表于 1997 年，常见的遗忘门后来加入；以下讲解带遗忘门、无窥孔连接的常用版本，不能把全部方程都归为原始结构¹⁰。

令 $\mathbf{c}^{(t)} \in \mathbb{R}^m$ 是记忆状态， $\mathbf{h}^{(t)} \in \mathbb{R}^m$ 是隐藏输出。门均读取 $[\mathbf{x}_t; \mathbf{h}^{(t-1)}] \in$

¹⁰ S. Hochreiter, J. Schmidhuber, *Long Short-Term Memory In Neural Computation*, 1997, vol. 9, no. 8, pp. 1735–1780

$\mathbb{R}^{d+m}$, 计算

$$\begin{aligned} \mathbf{i}^{(t)} &= \text{sigmoid}(\mathbf{A}_i[\mathbf{x}_t; \mathbf{h}^{(t-1)}] + \mathbf{b}_i), \\ \mathbf{f}^{(t)} &= \text{sigmoid}(\mathbf{A}_f[\mathbf{x}_t; \mathbf{h}^{(t-1)}] + \mathbf{b}_f), \\ \mathbf{o}^{(t)} &= \text{sigmoid}(\mathbf{A}_o[\mathbf{x}_t; \mathbf{h}^{(t-1)}] + \mathbf{b}_o), \\ \tilde{\mathbf{c}}^{(t)} &= \tanh(\mathbf{A}_c[\mathbf{x}_t; \mathbf{h}^{(t-1)}] + \mathbf{b}_c). \end{aligned} \quad (10.21)$$

每个 $\mathbf{A}$ 属于 $\mathbb{R}^{m \times (d+m)}$, 每个偏置属于 $\mathbb{R}^m$ 。输入门 $\mathbf{i}^{(t)}$ 决定候选记忆写入多少, 遗忘门 $\mathbf{f}^{(t)}$ 决定旧记忆保留多少, 输出门 $\mathbf{o}^{(t)}$ 决定记忆的变换结果读出多少:

$$\begin{aligned} \mathbf{c}^{(t)} &= \mathbf{f}^{(t)} \odot \mathbf{c}^{(t-1)} + \mathbf{i}^{(t)} \odot \tilde{\mathbf{c}}^{(t)}, \\ \mathbf{h}^{(t)} &= \mathbf{o}^{(t)} \odot \tanh(\mathbf{c}^{(t)}). \end{aligned} \quad (10.22)$$

遗忘门名称容易造成误读: 门值接近 1 是保留, 接近 0 才是清除。新旧信息在记忆路径上相加, 隐藏输出则经过 Tanh 和输出门, 记忆状态可以保留当前未必需要输出的信息。遗忘门使持续运行的网络能够清除不再相关的旧内容¹¹。

图 10.8 把各门的作用放在同一计算图中。三个 Sigmoid 模块输出门值, 控制“通过多少”; 与它们并排的 Tanh 模块产生候选记忆 $\tilde{\mathbf{c}}^{(t)}$, 提供“写入什么”, 数值可以为正或负。门与候选都取决于当前输入和此前状态, 因此同一单元可以在不同输入位置采用不同的保留和写入策略。

如果暂把门与候选值看作已给定量, 记忆路径对旧记忆的直接导数为 $\text{diag}(\mathbf{f}^{(t)})$ 。沿这条路径从 s 到 t 有

$$\left. \frac{\partial \mathbf{c}^{(t)}}{\partial \mathbf{c}^{(s)}} \right|_{\text{direct}} = \text{diag} \left(\prod_{u=s+1}^t \mathbf{f}^{(u)} \right), \quad (10.23)$$

乘积按坐标进行。与普通 RNN 的 $\mathbf{DW}$ 相比, 这条路径用可学习的保留率替代反复稠密混合; 需要保存的坐标可令遗忘门接近 1, 并用较小输入门减少覆盖。这改变了式(10.11)中的逐步增益, 通常没有缩短传播步数。但完整状态的雅可比还包含 $\mathbf{h}^{(t-1)}$ 影响各门和候选记忆的其他路径, 不能把直接路径系数当作整个总导数。

示例 10.4 门值决定保留和写入 考察一个记忆坐标, 假设旧值为 2, 本步遗忘门为 0.9、输入门为 0.2、候选值为 0.5。沿图 10.8 读取, 左上 $\odot$ 保留 $0.9 \times 2 = 1.8$, 中间 $\odot$ 写入 $0.2 \times 0.5 = 0.1$, 再由上方 $+$ 得到新记忆 1.9。若输出门为 0.5, 右侧 $\odot$ 产生隐藏输出 $0.5 \tanh(1.9) \approx 0.478$, 而非直接输出记忆值 1.9。

若之后 100 步不写入且遗忘门都为 0.99, 这份记忆沿直接路径的保留比例为 $0.99^{100} \approx 0.366$; 门值为 0.9 时仅约 2.66×10^{-5} 。加性记

¹¹ F. A. Gers, J. Schmidhuber, F. Cummins, *Learning to Forget: Continual Prediction with LSTM* In *Neural Computation*, 2000, vol. 12, no. 10, pp. 2451–2471




图 10.8 LSTM 更新与任务读出。框外左侧为当前输入 x_t 和旧状态 $h^{(t-1)}, c^{(t-1)}$ ，右侧为新状态和预测 $\hat{y}_t = g(Vh^{(t)} + c)$ 。蓝、红、黄三色分别区分遗忘门、输入门和输出门，Tanh 框产生候选记忆；圆形 $\odot$ 与 $+$ 分别表示逐元素乘法和相加。底部小图说明门值 0 阻断信息、门值 1 让信息通过。

忆路径改善了可选择的传播方式，并不意味着遗忘门小于 1 时永不衰减。

图 10.9 把例 10.4 扩展到两个记忆坐标。第一通道取较大的遗忘门和较小的输入门，主要保留旧值；第二通道反过来，主要写入候选值。 $\odot$ 只在相同坐标之间相乘，不会把第一通道的门值作用到第二通道。这正是门控的通道级选择语义。

记忆保持与信息读出仍要同时满足。即使直接路径没有明显衰减，过多写入也会覆盖证据；输出门较小或 $\tanh(c)$ 饱和时，任务损失仍可能难以作用于这段记忆。LSTM 提供按任务选择保留、写入和读出的机制，完整梯度与预测表现需要对整个状态和读出分析。

训练仍使用 BPTT，只需对记忆和隐藏两组状态共同求导。仅计上述单元，参数量为 $4m(d + m + 1)$ ，每步稠密仿射计算为 $O(m(d + m))$ ，常数来自四组变换。增大初始遗忘门偏置可使初始保留比例较高，但门饱和也会




图 10.9 二维 LSTM 的一步数值走查。蓝色与深灰数字分别表示两个通道；保留分支计算 $f \odot c^{(t-1)}$ ，写入分支计算 $i \odot \tilde{c}$ ，二者相加得到新记忆，再经 $o \odot \tanh(c^{(t)})$ 得到隐藏状态。所有数值均由图内向量逐坐标计算，第二通道结果为 $0.9 \tanh(0.5) \approx 0.416$ 。图中暂把门值和候选值视为已知，不展开它们的仿射计算。

减小自身的导数；这一选择需与长度和输入尺度匹配。

变体通常改变某条信息通路。**窥孔连接**（peephole connections）让门额外读取记忆坐标；耦合输入门与遗忘门可令 $i^{(t)} = 1 - f^{(t)}$ ，减少一组自由门。这些变体改变了门的依赖或自由度，适合程度需要在具体任务上比较¹²。

若希望保留较宽记忆而减少循环映射成本，投影 LSTM 把记忆输出映射到更小的循环隐藏空间，使记忆宽度和循环宽度分开。它改变参数量与状态依赖，比较时不能再直接使用上述等宽单元的计数¹³。

10.4.2 GRU

若希望简化状态管理，可以把记忆与隐藏输出合为一组变量。**门控循环单元**（gated recurrent unit, GRU）用更新门决定旧状态与候选状态的混合比例，用重置门控制候选计算怎样读取旧状态。这里采用 Cho 等原始形式的记号：更新门值越大，旧状态保留越多¹⁴。

对同宽状态，方程为

$$\begin{aligned} z^{(t)} &= \text{sigmoid}(U_z x_t + W_z h^{(t-1)} + b_z), \\ r^{(t)} &= \text{sigmoid}(U_r x_t + W_r h^{(t-1)} + b_r), \\ \tilde{h}^{(t)} &= \tanh(U_h x_t + W_h (r^{(t)} \odot h^{(t-1)}) + b_h), \\ h^{(t)} &= z^{(t)} \odot h^{(t-1)} + (1 - z^{(t)}) \odot \tilde{h}^{(t)}. \end{aligned} \quad (10.24)$$

每组 U 、 W 和偏置的形状与普通 RNN 相同。重置门接近零时，候选计算

¹² K. Greff, R. K. Srivastava, J. Koutnik, B. R. Steunebrink, J. Schmidhuber, *LSTM: A Search Space Odyssey* In IEEE Transactions on Neural Networks and Learning Systems, 2017, vol. 28, no. 10, pp. 2222–2232

¹³ H. Sak, A. Senior, F. Beaufays, *Long Short-Term Memory Based Recurrent Neural Network Architectures for Large Vocabulary Speech Recognition* In arXiv preprint arXiv:1402.1128, 2014

¹⁴ K. Cho, B. van Merriënboer, C. Gulcehre, D. Bahdanau, F. Bougares, H. Schwenk, Y. Bengio, *Learning Phrase Representations using RNN Encoder–Decoder for Statistical Machine Translation* In Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing, 2014, pp. 1724–1734

弱化旧状态；更新门接近 1 时，即使候选发生变化，输出也主要保留旧值。这两个门控制的位置不同，不能把重置旧信息与写入候选当作同一个动作。

图 10.10 显示了候选分支和保留分支。单独看保留分支，其直接传播系数为 $z^{(t)}$ ；完整导数还包含门和候选的变化，边界与 LSTM 相同。




图 10.10 GRU 更新与任务读出。左侧输入为 x_t 和旧状态 $h^{(t-1)}$ ，右侧输出为新状态与预测。组合输入将当前输入与旧状态一并送入门和候选模块。重置门参与候选计算；顶部两个 $\odot$ 框则显式形成 $z^{(t)} \odot \tilde{h}^{(t)}$ 与 $(1 - z^{(t)}) \odot h^{(t-1)}$ ，再相加得到新状态。读出 g 另将新状态映射为任务预测。

GRU 的长期保留对应更新门调节的直达分支。在需要延续记忆的坐标上， $z^{(t)}$ 接近 1 时，状态更新接近复制旧值，沿保留路径的系数为各步 z 的逐坐标乘积。候选分支的权重 $1 - z$ 同时较小，减少无关新输入覆盖已有状态。更新门接近 0 时则更多采用候选，允许网络改变当前记忆内容。

重置门的作用发生在候选计算中：它决定形成新候选时读取多少旧状态，而不是单独保证旧状态继续保存。重置门接近 0、更新门接近 1 时，网络仍可以保留旧状态；更新门接近 0 时，即使重置门较大，旧信息也要通过非线性候选重新表达。没有独立记忆状态与输出门，还使 GRU 的保留内容和当前对外表示耦合得更紧。门接近恒等复制能改善一条梯度路径，门饱和、候选混合及读出仍可能限制长期学习。

在只用一组偏置的上述形式中，GRU 单元参数量为 $3m(d + m + 1)$ ，少于等宽 LSTM 的四组变换，也只维护一个 m 维状态。代价是没有独立的记忆状态和输出门，存储与对外表示更直接地耦合。参数更少不能单独推出任务性能更好，应在相近参数预算与预测条件下比较。

文献与软件还存在不同约定：有的把更新门定义为新候选的写入比例，有的把重置门放在 $\mathbf{W}_h \mathbf{h}^{(t-1)}$ 之后。前一种可通过交换 $\mathbf{z}$ 与 $1 - \mathbf{z}$ 对应，后一种一般不能交换矩阵乘法与逐元素乘法，因此并非完全相同的更新。复现时应核对方程、偏置组数和门顺序，不能只核对模型名。

10.5 基于注意力的循环神经网络

在式(10.5)中，全部输入只能经由同一个上下文向量被解码器读取。输入越长，需要同时保存和区分的细节可能越多；即使编码器使用 LSTM，固定向量读出仍然要求不同生成步从同一压缩结果中恢复各自所需的信息。可以保留每个输入位置的编码状态，让解码器在生成每个符号时重新选择读取位置。

10.5.1 注意力机制

注意力机制 (attention mechanism) 根据当前计算需求给一组表示分配权重，再加权聚合：解码器需要的信息改变时，读取的上下文也随之改变。令编码器状态为 $\mathbf{h}_1, \dots, \mathbf{h}_T \in \mathbb{R}^m$ ，这里下标表示被保存的位置， $\mathbf{h}_t = \mathbf{h}^{(t)}$ 。对第 j 个解码步，给定查询 $\mathbf{q}^{(j)} \in \mathbb{R}^r$ ，计算

$$\begin{aligned} e_{j,t} &= a(\mathbf{q}^{(j)}, \mathbf{h}_t), \\ \alpha_{j,t} &= \frac{\exp(e_{j,t})}{\sum_{u=1}^T \exp(e_{j,u})}, \\ \mathbf{c}^{(j)} &= \sum_{t=1}^T \alpha_{j,t} \mathbf{h}_t. \end{aligned} \quad (10.25)$$

评分函数 a 比较查询与候选表示的相关程度。Softmax 使权重非负且总和为 1， $\mathbf{c}^{(j)}$ 是本步的动态上下文。填充位置应在归一化前排除，不能让不存在的输入分走概率。对很大的得分减去最大值再取指数，不改变权重，却可避免指数溢出。

评分可以通过非线性组合学习，也可以使用内积。**加性注意力** (additive attention) 先把查询和编码状态投影到同一评分空间，再给出标量：

$$e_{j,t} = \mathbf{v}_a^\top \tanh(\mathbf{W}_q \mathbf{q}^{(j)} + \mathbf{W}_h \mathbf{h}_t + \mathbf{b}_a). \quad (10.26)$$

设评分空间宽度为 a ，则 $\mathbf{W}_q \in \mathbb{R}^{a \times r}$ 、 $\mathbf{W}_h \in \mathbb{R}^{a \times m}$ 、 $\mathbf{v}_a, \mathbf{b}_a \in \mathbb{R}^a$ 。它允许查询和编码状态原本具有不同维度。

点积注意力 (dot-product attention) 直接用内积评分, 在 $r = m$ 时可取 $e_{j,t} = \langle \mathbf{q}^{(j)}, \mathbf{h}_t \rangle$; 一般形式可取 $e_{j,t} = (\mathbf{q}^{(j)})^\top \mathbf{W}_a \mathbf{h}_t$, 其中 $\mathbf{W}_a \in \mathbb{R}^{r \times m}$ 。点积形式便于批量矩阵计算, 加性形式通过额外非线性改变评分函数, 两者的适合程度仍由任务和宽度决定。Transformer 章会继续讨论缩放、多头和位置编码, 这里只需理解评分、归一化和聚合。

示例 10.5 权重与上下文 假设本步对三个位置的得分为 $0, \log 2, 0$, 相应状态为 $(1, 0)^\top, (0, 2)^\top, (1, 1)^\top$ 。归一化权重为 $(1/4, 1/2, 1/4)$, 上下文为 $(1/2, 5/4)^\top$ 。第二个位置贡献较大, 但上下文仍混合了三个状态; 软权重并不是一次离散选择, 也不能仅凭权重大小认定某位置是预测的唯一原因。

10.5.2 网络结构

动态上下文可以参与解码状态更新, 也可以在更新后参与输出。Bahdanau 等的模型用此前解码状态查询编码表示, 先形成 $\mathbf{c}^{(j)}$, 再计算本步状态:

$$\begin{aligned} \mathbf{q}^{(j)} &= \mathbf{s}^{(j-1)}, \\ \mathbf{s}^{(j)} &= F_{\text{dec}}(\mathbf{s}^{(j-1)}, \mathbf{e}(y_{j-1}), \mathbf{c}^{(j)}), \\ \mathbf{p}^{(j)} &= G(\mathbf{s}^{(j)}, \mathbf{c}^{(j)}, \mathbf{e}(y_{j-1})). \end{aligned} \quad (10.27)$$

G 是输出概率映射, 包含所需的可学习变换和归一化。编码器可以双向读取输入, 使每个位置的表示同时包含前后上下文; 这仍是输入侧的离线读取, 不代表解码器可以看到未来目标¹⁵。

Luong 等则先计算本步解码状态, 再用该状态查询, 形成融合后的输出表示:

$$\begin{aligned} \mathbf{s}^{(j)} &= F_{\text{dec}}(\mathbf{s}^{(j-1)}, \mathbf{e}(y_{j-1})), \\ \mathbf{q}^{(j)} &= \mathbf{s}^{(j)}, \quad \tilde{\mathbf{s}}^{(j)} = \tanh(\mathbf{W}_c[\mathbf{s}^{(j)}; \mathbf{c}^{(j)}]), \\ \mathbf{p}^{(j)} &= \text{softmax}(\mathbf{V}_a \tilde{\mathbf{s}}^{(j)} + \mathbf{b}_a). \end{aligned} \quad (10.28)$$

其输入馈送变体还把前一步融合表示送入下一步解码。两个模型的关键区别之一是查询产生的时机和上下文进入的路径, 不能直接把当前状态查询放进式(10.27)而保留其余依赖不变, 否则会形成未说明如何求解的同一步循环¹⁶。

全局注意力 (global attention) 对全部有效输入位置评分, 生成 S 个符号通常需要 ST 个位置对评分。**局部注意力** (local attention) 只考虑某个位置附近的窗口, 可固定窗口推进方式, 也可由状态预测中心。窗口降低了读取范围与评分数量, 但可能遗漏远处证据; 可学习中心、连续位置权重和边界处理还需明确。局部方法不是全局权重自然变尖后的同义名称。

图 10.11 采用先查询、后更新的组织方式。保存的编码状态建立了一条

¹⁵ D. Bahdanau, K. Cho, Y. Bengio, *Neural Machine Translation by Jointly Learning to Align and Translate* In International Conference on Learning Representations, 2015

¹⁶ T. Luong, H. Pham, C. D. Manning, *Effective Approaches to Attention-based Neural Machine Translation* In Proceedings of the 2015 Conference on Empirical Methods in Natural Language Processing, 2015, pp. 1412–1421

从输出直接读取早期位置的路径，减轻了所有细节只能经过编码末状态的限制。它同时需要保存整段编码表示，每个生成步还要执行读取，代价与固定状态读出不同。




图 10.11 带注意力的一个解码步。左侧为保存的编码状态 $\mathbf{h}_{1:T}$ 、旧解码状态和此前目标的嵌入，右侧为新解码状态和输出概率。查询先用旧解码状态产生权重 $\alpha_j = (\alpha_{j,1}, \dots, \alpha_{j,T})$ ，上下文再进入更新与输出映射；输出映射还可读取目标嵌入。编码状态在各解码步重复读取，图中不重新执行编码器。

注意力对长期依赖的作用，可以从读取路径直接看出。暂固定本步评分和权重时，动态上下文对第 t 个编码状态的直接导数为

$$\left. \frac{\partial \mathbf{c}^{(j)}}{\partial \mathbf{h}_t} \right|_{\alpha_j \text{ fixed}} = \alpha_{j,t} \mathbf{I}_o \quad (10.29)$$

该分支从上下文直接到保存的表示，不再要求第 t 个状态经过其后全部编码状态才能被读取。权重若均匀，系数为 $1/T$ ；若本步评分集中于相关位置，相应系数可以更大。这与普通时间链上的指数连乘具有不同的路径结构。

注意力没有取消编码器中的历史压缩，也没有保证评分一定找到证据。某个输入影响 $\mathbf{h}_t$ 之前仍经过编码计算，过早丢失的信息无法靠读取恢复；错误或过度分散的权重也会弱化相关表示。保存各位置状态扩大了可访问范围，代价是随源长度增长的存储和读取。完整导数还包含评分随编码状态变化的分支，下一小节会把它与编码器、解码器的时间梯度合在一起。

10.5.3 参数学习

编码器、评分函数、解码器和输出层可以按式(10.6)联合学习。软聚合可微，无需为每个目标另给一个位置标签。要理解注意力如何收到监督，暂固定查询并只看一个上下文节点。令 $\mathbf{g}_c^{(j)} = \partial L / \partial \mathbf{c}^{(j)}$ ，Softmax 导数给出

$$\frac{\partial L}{\partial e_{j,t}} = \alpha_{j,t} \langle \mathbf{g}_c^{(j)}, \mathbf{h}_t - \mathbf{c}^{(j)} \rangle. \quad (10.30)$$

其来源是 $\partial \alpha_{j,u} / \partial e_{j,t} = \alpha_{j,u} (\mathbf{1}_{\{u=t\}} - \alpha_{j,t})$ 。增加某个得分会提高对应状态的相对权重，并降低其他权重；所以梯度比较的是该状态与当前平均上下文的差异，而不是仅看该状态的绝对值。

对编码状态还存在直接聚合贡献 $\alpha_{j,t} \mathbf{g}_c^{(j)}$ ，以及该状态改变评分产生的间接贡献。多个解码步的贡献相加后，再沿编码器的时间依赖回传；查询和解码状态也收到评分路径与输出路径的梯度。注意力缩短了部分信息与梯度路径，但编码器和解码器仍有循环依赖，权重过度集中或趋于零也可能削弱某些位置的监督。

10.6 状态空间模型

门控和注意力改善了信息选择，却没有使任意非线性循环单元的时间依赖自动并行化。另一种设计从状态转移的代数形式入手：让每一步更新能被高效组合，再在状态模块外加入投影、非线性与跨层连接。这里的**状态空间模型**（state space model, SSM）指用于神经序列网络的状态更新与读出模块；这个名称在控制和概率建模中还有更广含义，本节不讨论随机状态估计的完整框架。

10.6.1 状态空间表示与并行计算基础

对连续输入 $\mathbf{x}(\tau) \in \mathbb{R}^d$ ，线性状态空间表示为

$$\frac{d\mathbf{h}(\tau)}{d\tau} = \mathbf{A}\mathbf{h}(\tau) + \mathbf{B}\mathbf{x}(\tau), \quad \mathbf{y}(\tau) = \mathbf{C}\mathbf{h}(\tau) + \mathbf{D}\mathbf{x}(\tau). \quad (10.31)$$

其中 $\mathbf{h}(\tau) \in \mathbb{R}^m$ ， $\mathbf{A} \in \mathbb{R}^{m \times m}$ 、 $\mathbf{B} \in \mathbb{R}^{m \times d}$ 、 $\mathbf{C} \in \mathbb{R}^{q \times m}$ 、 $\mathbf{D} \in \mathbb{R}^{q \times d}$ ； $\mathbf{D}$ 给出当前输入直达输出的通路。 τ 表示连续时间，避免与离散步数 t 混淆。此处先固定矩阵和步长，称为**线性时不变**（linear time-invariant, LTI）：叠加成立，转移规则也不随时间位置改变。

如果每个采样区间长 $\Delta > 0$ 且输入在区间内保持常值，解线性微分方程

得到**零阶保持离散化** (zero-order hold discretization):

$$\begin{aligned}\bar{\mathbf{A}} &= \exp(\Delta \mathbf{A}), & \bar{\mathbf{B}} &= \int_0^\Delta \exp(u\mathbf{A})\mathbf{B} du, \\ \mathbf{h}^{(t)} &= \bar{\mathbf{A}}\mathbf{h}^{(t-1)} + \bar{\mathbf{B}}\mathbf{x}_t, & \mathbf{y}_t &= \mathbf{C}\mathbf{h}^{(t)} + \mathbf{D}\mathbf{x}_t.\end{aligned}\quad (10.32)$$

$\exp$ 是矩阵指数。 $\mathbf{A}$ 可逆时, 积分可写为 $\mathbf{A}^{-1}(\exp(\Delta \mathbf{A}) - \mathbf{I})\mathbf{B}$; 积分形式在不可逆时仍有意义。网络也可以直接学习离散矩阵, 不必总从连续方程出发。

在零初始状态、固定离散矩阵下, 反复代入递推可得

$$\begin{aligned}\mathbf{h}^{(t)} &= \sum_{u=1}^t \bar{\mathbf{A}}^{t-u} \bar{\mathbf{B}} \mathbf{x}_u, \\ \mathbf{y}_t &= \sum_{k=0}^{t-1} \mathbf{K}_k \mathbf{x}_{t-k} + \mathbf{D} \mathbf{x}_t, & \mathbf{K}_k &= \mathbf{C} \bar{\mathbf{A}}^k \bar{\mathbf{B}}.\end{aligned}\quad (10.33)$$

$\mathbf{K}_k \in \mathbb{R}^{q \times d}$ 是滞后 k 步的响应。它只依赖滞后而不依赖绝对位置, 所以输出是一个因果卷积。非零初态还会增加 $\mathbf{C} \bar{\mathbf{A}}^t \mathbf{h}^{(0)}$; 时间变化或输入相关的系数一般不能并入同一个固定卷积核。

并行计算还有另一条基础。对已知的仿射更新 $\mathbf{h}^{(t)} = \mathbf{A}_t \mathbf{h}^{(t-1)} + \mathbf{b}_t$, 用二元组 $(\mathbf{A}_t, \mathbf{b}_t)$ 表示一步变换。先执行 P 再执行 Q 的组合定义为

$$(\mathbf{A}_Q, \mathbf{b}_Q) \circ (\mathbf{A}_P, \mathbf{b}_P) = (\mathbf{A}_Q \mathbf{A}_P, \mathbf{A}_Q \mathbf{b}_P + \mathbf{b}_Q). \quad (10.34)$$

函数复合满足结合律, 因此可以使用**关联扫描** (associative scan): 把连续片段的变换先组合, 再得到所有前缀变换。它保持原来的时间次序, 不要求交换律。图 10.12 示意组合过程。




图 10.12 仿射状态更新的有序组合。四个单步变换先组成两个连续片段, 再组成整段; $Q \circ P$ 表示先执行 P 再执行 Q 。平衡组合树展示的是扫描中的汇总阶段, 完整前缀扫描还要把此前片段的结果传给各位置, 才能得到每步状态。树形计算可缩短依赖深度, 但不改变输入顺序。

对逐坐标仿射更新，工作高效的扫描可用 $O(Tm)$ 总运算量和 $O(\log T)$ 组合深度得到前缀；稠密矩阵的组合却需要矩阵乘法，不能直接沿用这一成本。普通 RNN 的非线性组合也通常无法保持固定大小、便于计算的仿射表示。可并行的条件是各步系数可提前取得、组合闭合且足够便宜；若系数必须由尚未计算的旧状态产生，就不能直接预先扫描。

示例 10.6 同一状态模型的递推与卷积 取标量更新 $h^{(t)} = \frac{1}{2}h^{(t-1)} + x_t$ 、 $y_t = h^{(t)}$ 、 $h^{(0)} = 0$ ，输入为 $(1, 2, 0)$ 。递推得到 $(1, 5/2, 5/4)$ 。卷积核为 $(1, 1/2, 1/4, \dots)$ ，故第三步输出为 $0 + \frac{1}{2} \times 2 + \frac{1}{4} \times 1 = 5/4$ 。整段训练可以按卷积组织，逐步预测可以按状态组织；相同输出来自相同模型的代数等价，而不是两套分别训练的参数。

10.6.2 HiPPO

前述矩阵形式还没有回答状态应保存哪种历史。**高阶多项式投影** (high-order polynomial projection operators, HiPPO) 把记忆写成一个明确的近似问题：用有限个多项式基函数的系数概括此前输入。相比只保存一个滑动平均，多个系数可以描述历史中的不同变化形态¹⁷。

10.6.2.1 投影系数保存什么

设标量历史信号为 $f(u)$ ，在当前时刻 τ 选定历史权重测度 μ_τ 和相应正交归一基 $p_0(u; \tau), \dots, p_{m-1}(u; \tau)$ 。在该测度下平方可积时，投影系数与近似信号为

$$c_i(\tau) = \int f(u) p_i(u; \tau) d\mu_\tau(u), \quad \hat{f}_\tau(u) = \sum_{i=0}^{m-1} c_i(\tau) p_i(u; \tau). \quad (10.35)$$

它在所选 m 维基函数空间中最小化加权平方误差。状态是这些系数，而不是每个历史位置的副本；被权重弱化或超出基函数分辨能力的细节仍可能丢失。

10.6.2.2 在线更新与网络组织

例如缩放 Legendre 版本在 $[0, \tau]$ 上采用均匀权重，将整个历史区间缩放到固定区间上的 Legendre 多项式。使用从零开始的 $i, j \in \{0, \dots, m-1\}$ ，其

¹⁷ A. Gu, T. Dao, S. Ermon, A. Rudra, C. Ré, *HiPPO: Recurrent Memory with Optimal Polynomial Projections* In Advances in Neural Information Processing Systems 33, 2020, pp. 1474–1487

连续系数更新可写为

$$\frac{d\mathbf{c}(\tau)}{d\tau} = -\frac{1}{\tau}\mathbf{H}\mathbf{c}(\tau) + \frac{1}{\tau}\mathbf{b}f(\tau), \quad \tau > 0, \quad (10.36)$$

$$H_{i,j} = \begin{cases} \sqrt{(2i+1)(2j+1)}, & i > j, \\ i+1, & i = j, \\ 0, & i < j, \end{cases} \quad b_i = \sqrt{2i+1}.$$

随时间变化的 $1/\tau$ 反映历史区间不断扩张，不能直接把这一更新称为固定 LTI 系统。 $m=1$ 时， c_0 是整个区间的均值，其导数为 $(f(\tau) - c_0(\tau))/\tau$ ，这给出了系数更新的直观核验。离散实现需选择初始化和离散化，不能在 $\tau=0$ 直接代入。

测度决定“哪些历史值得近似”：固定窗口强调近期区间，指数权重弱化久远输入，随时间扩张的均匀区间覆盖全部过去，但固定阶数的分辨率会受到区间增长影响。HiPPO 提供状态构造原则和相应结构矩阵，完整预测网络仍需要输入变换、读出及学习目标。可以固定投影动态、学习前后变换，也可以以结构矩阵初始化后再调整；后者需要重新检查状态是否仍满足原来的投影含义。投影误差的性质不能直接代替任务泛化误差。

图 10.13 展示了一种把投影记忆接入任务网络的方式。实际观测可先经过可学习映射形成 $f(\tau)$ ；投影更新维护系数，任务读出利用系数产生预测。若输入有多个特征，可以为各通道分别维护一组系数，再混合通道。重构历史使用已选定的基函数，任务读出则由监督目标决定，两者用途不同。




图 10.13 HiPPO 投影记忆与任务网络的一种组合。红色反馈维护系数状态，黄色读出产生任务预测；下方将同一系数与基函数组合，近似重构历史信号。HiPPO 本身规定记忆表示及更新，图中的任务读出与输入特征映射可另行学习，并非唯一的 HiPPO 网络架构。

若投影动态固定，任务损失训练输入映射和读出；输入映射可学习时，梯度仍需经过投影递推回到此前输入特征。若进一步训练投影矩阵，模型获得调整动态的自由，也放松了投影所规定的约束。描述模型时应明确哪些参数固定，不能同时宣称任意训练后的矩阵仍严格实现原来的最优投影。

10.6.2.3 历史覆盖与长期依赖的边界

LegS 把全部过去放进随时间扩张的区间，没有用一个固定窗口把早期输入直接删除。最低阶系数是均值：在 $[0, \tau]$ 上， $c_0(\tau) = \tau^{-1} \int_0^\tau f(u) du$ 。时刻 u 附近面积为 ε 的窄脉冲，对这个均值的贡献约为 ε/τ ，随当前时刻按倒数减弱，而不是按已经经过的更新步数以固定比例反复衰减。

这个性质也可从状态更新看出。对 $0 < \sigma < \tau$ ，将 $[\sigma, \tau]$ 间的输入固定，初始系数扰动满足

$$\delta \mathbf{c}(\tau) = \exp[-\mathbf{H} \log(\tau/\sigma)] \delta \mathbf{c}(\sigma). \quad (10.37)$$

因为此区间的齐次更新是 $\delta \dot{\mathbf{c}} = -\mathbf{H} \delta \mathbf{c}/\tau$ ，积分变量是 $\log \tau$ 。与固定矩阵的 $\exp(\mathbf{A}(\tau - \sigma))$ 相比，LegS 按时间比值组织保留；最低阶模式的系数为 σ/τ 。矩阵的其他模式与范数常数仍需计入，不能由最低阶模式推出所有任务梯度都不衰减。

多个系数提供的不是多个历史位置，而是多个形状特征。取 $p_0 = 1$ 、 $p_1 = \sqrt{3}(2u/\tau - 1)$ ，对线性历史 $f(u) = a + bu$ ，两个系数为

$$c_0 = a + \frac{b\tau}{2}, \quad c_1 = \frac{b\tau}{2\sqrt{3}}. \quad (10.38)$$

代回基函数组合即可精确恢复这条线性函数：第一个系数保存水平，第二个补上趋势。若历史含有很多窄尖峰，两个系数便不足以定位每个尖峰；提高阶数增加分辨能力，也增加状态与计算成本。

因此，HiPPO 把长期记忆转为有明确误差准则的在线压缩。它适合考察较长区间上的形状和趋势，固定阶数、有限精度、所选测度与信号变化共同限制可恢复细节。模型若需要精确取回任意久远符号，还需检验相应信息在投影后是否可区分；任务网络的非线性与读出同样可能带来额外学习困难。

10.6.3 S4

利用式(10.33)并行训练，还需要高效产生长度为 T 的卷积核。稠密 $m \times m$ 矩阵逐步计算 $\overleftarrow{\mathbf{A}}^k \overleftarrow{\mathbf{B}}$ 需要重复矩阵向量乘法；直接对某些 HiPPO 矩阵进行普通对角化又可能数值不稳定。**结构化状态空间序列模型** (structured state

space sequence model, S4) 利用状态矩阵的特殊分解加快递推与核生成¹⁸。

10.6.3.1 结构矩阵与核生成

其关键结构之一是**对角加低秩** (diagonal plus low-rank, DPLR): 在合适的复数坐标系中写为

$$\mathbf{A} = \mathbf{\Lambda} - \mathbf{P}\mathbf{Q}^*, \quad (10.39)$$

其中 $\mathbf{\Lambda} \in \mathbb{C}^{m \times m}$ 是对角矩阵, $\mathbf{P}, \mathbf{Q} \in \mathbb{C}^{m \times r}$, 秩 r 较小, $*$ 表示共轭转置。这个坐标系来自正规矩阵加低秩结构的酉变换; 正规矩阵 $\mathbf{N}$ 满足 $\mathbf{N}\mathbf{N}^* = \mathbf{N}^*\mathbf{N}$, 其酉对角化避免任意病态基变换, 加入低秩项后的 $\mathbf{A}$ 则不必正规。输入和输出映射也随坐标一起变换, 实际输出可通过共轭配对保持实数。

S4 采用的双线性离散化为

$$\begin{aligned} \bar{\mathbf{A}} &= (\mathbf{I} - \frac{\Delta}{2}\mathbf{A})^{-1}(\mathbf{I} + \frac{\Delta}{2}\mathbf{A}), \\ \bar{\mathbf{B}} &= (\mathbf{I} - \frac{\Delta}{2}\mathbf{A})^{-1}\Delta\mathbf{B}, \end{aligned} \quad (10.40)$$

需保证逆矩阵存在。DPLR 形式使相关逆矩阵作用可以通过对角运算和低秩修正计算; 固定秩时, 一步递推可达到 $O(m)$ 量级, 而不是稠密状态转移的 $O(m^2)$ 。

核生成也利用这套结构。把长度为 T 的核视为一个有限多项式, 用几何和恒等式可写为

$$\begin{aligned} \mathbf{G}_T(z) &= \sum_{k=0}^{T-1} \mathbf{K}_k z^k \\ &= \mathbf{C} \left[\mathbf{I} - (z\bar{\mathbf{A}})^T \right] (\mathbf{I} - z\bar{\mathbf{A}})^{-1} \bar{\mathbf{B}}, \end{aligned} \quad (10.41)$$

第二行适用于所写逆矩阵存在时, T 表示有限核长度, 矩阵上的 T 是幂次而非转置。要看清这个逆怎样利用 DPLR 结构, 下面固定单输入单输出情形, 记 $\mathbf{B} = \mathbf{b}$, $\mathbf{C} = \mathbf{c}^*$, 其中 $\mathbf{b}, \mathbf{c} \in \mathbb{C}^m$; 此时 $\mathbf{G}_T$ 退化为标量多项式 G_T , 低秩 r 不随 m, T 增长。

由双线性离散化,

$$\mathbf{I} - z\bar{\mathbf{A}} = (\mathbf{I} - \frac{\Delta}{2}\mathbf{A})^{-1} \left[(1-z)\mathbf{I} - \frac{\Delta}{2}(1+z)\mathbf{A} \right].$$

对 $z \neq -1$, 提出方括号中的系数, 可将离散逆矩阵作用改写为

$$\begin{aligned} \xi(z) &= \frac{2}{\Delta} \frac{1-z}{1+z}, \\ (\mathbf{I} - z\bar{\mathbf{A}})^{-1} \bar{\mathbf{b}} &= \frac{2}{1+z} (\xi(z)\mathbf{I} - \mathbf{A})^{-1} \mathbf{b}. \end{aligned} \quad (10.42)$$

¹⁸ A. Gu, K. Goel, C. Ré, *Efficiently Modeling Long Sequences with Structured State Spaces* In International Conference on Learning Representations, 2022

其中 $\bar{\mathbf{b}} = (\mathbf{I} - \Delta\mathbf{A}/2)^{-1}\Delta\mathbf{b}$ 。右侧的 $(\xi\mathbf{I} - \mathbf{A})^{-1}$ 称为预解矩阵 (resolvent)。双线性变换把离散频率点 z 转为连续状态矩阵的频率变量 ξ ，上式仍以相关逆存在为前提。

有限长度因子不能在这一步丢掉。在 T 个单位根 $z_\ell = \exp(-2\pi i \ell / T)$ 、 $\ell = 0, \dots, T-1$ 上， i 为虚数单位， $z_\ell^T = 1$ ，因此可以共用修正后的输出行

$$\mathbf{c}_T^* = \mathbf{c}^*(\mathbf{I} - \bar{\mathbf{A}}^T)。(10.43)$$

代入式(10.41)与式(10.42)，对 $z_\ell \neq -1$ 得到

$$G_T(z_\ell) = \frac{2}{1 + z_\ell} \mathbf{c}_T^*(\xi(z_\ell)\mathbf{I} - \mathbf{A})^{-1}\mathbf{b}。(10.44)$$

这里利用 $z^T = 1$ 才把修正行统一为 $\mathbf{c}_T^*$ ；一般 z 处仍须保留 $\mathbf{I} - (z\bar{\mathbf{A}})^T$ ，不能直接改用 $\mathbf{I} - \bar{\mathbf{A}}^T$ 。

现在代入 $\mathbf{A} = \mathbf{\Lambda} - \mathbf{P}\mathbf{Q}^*$ 。记 λ_j 为 $\mathbf{\Lambda}$ 的第 j 个对角元素，并令

$$\mathbf{R}_\xi = (\xi\mathbf{I} - \mathbf{\Lambda})^{-1} = \text{diag}\left(\frac{1}{\xi - \lambda_1}, \dots, \frac{1}{\xi - \lambda_m}\right)。$$

Woodbury 恒等式把原来的 $m \times m$ 逆化为对角逆和一个 $r \times r$ 逆：

$$(\xi\mathbf{I} - \mathbf{A})^{-1} = \mathbf{R}_\xi - \mathbf{R}_\xi\mathbf{P}(\mathbf{I}_r + \mathbf{Q}^*\mathbf{R}_\xi\mathbf{P})^{-1}\mathbf{Q}^*\mathbf{R}_\xi。(10.45)$$

将其代入式(10.44)，只需计算 $\mathbf{c}_T^*\mathbf{R}_\xi\mathbf{b}$ 、 $\mathbf{c}_T^*\mathbf{R}_\xi\mathbf{P}$ 、 $\mathbf{Q}^*\mathbf{R}_\xi\mathbf{b}$ 和 $\mathbf{Q}^*\mathbf{R}_\xi\mathbf{P}$ ，再作小矩阵求逆与乘法。每个对象的元素都是如下形式的求和：

$$\mathbf{u}^*\mathbf{R}_\xi\mathbf{v} = \sum_{j=1}^m \frac{\bar{u}_j v_j}{\xi - \lambda_j}, (10.46)$$

其中 $\mathbf{u}$ 取 $\mathbf{c}_T$ 或 $\mathbf{Q}$ 的列， $\mathbf{v}$ 取 $\mathbf{b}$ 或 $\mathbf{P}$ 的列， $\bar{u}_j$ 表示复共轭。求和中的倒数因子 $1/(\xi(z_\ell) - \lambda_j)$ 就是 **Cauchy 核** (Cauchy kernel)。因此加速的对象是许多频率点共享谱参数的这组求和，而不是为每个频率重新求一个一般稠密逆矩阵。

上述分解要求 $\xi\mathbf{I} - \mathbf{\Lambda}$ 及低秩修正中的逆存在。若某个采样点使中间表达式奇异，应回到有限多项式求值，或使用已消去可去奇点的等价形式。偶数 T 还会包含 $z_{T/2} = -1$ ，此时不能直接计算 ξ ；由 $\mathbf{I} + \bar{\mathbf{A}} = 2(\mathbf{I} - \Delta\mathbf{A}/2)^{-1}$ 可单独得到

$$G_T(-1) = \frac{\Delta}{2} \mathbf{c}_T^* \mathbf{b} \quad (T \text{ 为偶数})。$$

取得全部 T 个单位根处的值后，逆 DFT 恢复长度为 T 的核系数，可用 FFT 实现。这里保留的是有限多项式的值，不是无限序列频率响应的直接采样。

固定秩下，逐点直接执行式(10.46)仍需 $O(mT)$ 求和工作，形成 $\mathbf{c}_T$ 也有

成本；上述恒等式本身并未证明近线性核生成。原始 S4 在相应快速结构算法下给出关于 $m + T$ 的近线性分析，具体算法与数值实现仍需另行核对。得到核后，LTI 状态模块可用适当补零的 FFT 卷积处理整段序列，单通道卷积的成本为 $O(T \log T)$ ，不能将它当成全部核生成成本。逐步预测改用同一组离散参数递推，无需保存全部历史输入。

10.6.3.2 完整层、训练与逐步预测

一个标量 SSM 只完成一条序列上的线性变换。完整 S4 层可为 d 个输入通道各设一个 m 维状态模块，得到 $\mathbf{y}_t \in \mathbb{R}^d$ ，再作非线性变换和逐位置通道混合，例如

$$\mathbf{u}_t = \mathbf{M} \phi(\mathbf{y}_t) + \mathbf{b}_{\text{mix}}, \quad \mathbf{M} \in \mathbb{R}^{d \times d}. \quad (10.47)$$

ϕ 逐坐标作用， $\mathbf{u}_t$ 是本层输出特征，可送入下一层或任务头。维度匹配时还可以加入跨层残差与归一化。时间模块传播各通道的历史，通道混合再使不同特征相互作用；多个这样的层构成非线性序列网络。

图 10.14 把同一层的两种计算方式并列。整段输入已经给定时，由结构参数生成因果卷积核，再对各通道计算卷积；逐步预测时，维护各通道状态并直接递推。外部非线性与通道映射相同，切换的是线性状态模块的计算形式。

整段计算




图 10.14 S4 层的整段与逐步计算。两个路径共享同一组离散状态参数及后续通道映射，虚线表示参数供给。零初态时，因果卷积与递推得到相同线性序列输出；非零初态需要补上对应初态响应。图中 $\mathbf{u}$ 是层输出特征，任务预测还需相应读出。

结构参数、输入输出映射、步长与通道映射由任务损失联合学习。卷积路径的反向计算对同一个核参数化求导，而不是另训练一套卷积权重；预测切到递推时，需要使用与训练一致的离散化、因果约定和初始化。整个网络可以非线性，卷积等价只针对满足 LTI 条件的状态模块。

HiPPO-LegS 的 $1/\tau$ 更新与 S4 中的固定结构动态也应分清。S4 借用结构矩阵和初始化思想，使网络可以学习有用的时间响应；它没有在每个时刻完整保留 LegS 投影语义。DPLR 结构首先服务于高效计算，训练后的稳定性与长期响应还要检查参数取值。

10.6.3.3 时间尺度与长期依赖

S4 保存多久，与离散状态矩阵的模式有关。在可对角化情形下， $\mathbf{K}_k = \mathbf{C}\mathbf{A}^{-k}\mathbf{B}$ 是多个指数模式的加权组合。某模式的特征值 $\bar{\lambda}_j$ 满足 $0 < |\bar{\lambda}_j| < 1$ 时，其幅度按 $|\bar{\lambda}_j|^k$ 衰减，相应以步数计的时间尺度为

$$\tau_{\text{steps},j} = -\frac{1}{\log |\bar{\lambda}_j|}。 \quad (10.48)$$

幅度经过这个步数约降到原来的 e^{-1} 。接近 1 的模式保留较久，较小的模式强调近期；复数模式还可表示振荡。不同时间尺度共同形成历史响应，输入映射决定往哪些模式写入，输出映射决定哪些模式参与预测。

对连续特征值 λ_j ，双线性离散化给出 $\bar{\lambda}_j = (1 + \Delta\lambda_j/2)/(1 - \Delta\lambda_j/2)$ 。左半平面的特征值映入单位圆内，步长又改变离散时间尺度。特征值只描述模式，非正规矩阵的短期放大与数值条件仍需考虑；结构可高效计算，也不代表任意自由参数都稳定。

长期影响在输入输出层面写为 $\partial \mathbf{y}_t / \partial \mathbf{x}_s = \mathbf{K}_{t-s}$ ， $s < t$ ；当前输入的导数还包含直接项 $\mathbf{D}$ 。卷积路径直接计算这个历史响应，训练时不必按普通 RNN 的非线性单元逐步展开；但同一映射的导数并没有因为改用 FFT 就变大。若核在相关距离已经衰减，早期证据仍然弱；若读写映射没有利用慢模式，长时间尺度也不会自动转成任务所需的记忆。

S4 因而同时改善状态的结构设计和整段计算。固定 LTI 模块对同一滞后使用同一响应，适合学习多尺度时间关系，却不能在单个模块中按每次输入的内容改写保留率。非线性堆叠扩展了网络表达，按内容选择状态的另一种做法则是下面的 Mamba。

10.6.4 Mamba

固定 LTI 更新对相同滞后使用相同响应。若输入流中只有某些符号需要保留，而它们出现的位置不固定，仅按滞后衰减便难以直接按内容筛选。Mamba 采用选择性状态空间更新，让部分系数由当前输入产生，改变哪些

内容写入、保留或读出。本节采用原始 Mamba 架构¹⁹。

10.6.4.1 选择性状态更新

为看清选择性，考察预处理后一个通道的标量输入 x_t 与 m 维状态。固定可学习的连续对角矩阵 $\mathbf{A}$ ，由当前输入特征产生 $\Delta_t > 0$ 、 $\mathbf{B}_t \in \mathbb{R}^m$ 和 $\mathbf{C}_t \in \mathbb{R}^{1 \times m}$ ，采用零阶保持时

$$\begin{aligned}\bar{\mathbf{A}}_t &= \exp(\Delta_t \mathbf{A}), \\ \bar{\mathbf{B}}_t &= \int_0^{\Delta_t} \exp(u\mathbf{A})\mathbf{B}_t du, \\ \mathbf{h}^{(t)} &= \bar{\mathbf{A}}_t \mathbf{h}^{(t-1)} + \bar{\mathbf{B}}_t x_t, \\ y_t &= \mathbf{C}_t \mathbf{h}^{(t)} + D x_t.\end{aligned}\tag{10.49}$$

D 是通道的直接输入系数。输入相关不要求 $\mathbf{A}$ 每步重新生成，选择性来自步长、写入和读出映射。多个通道各有状态，并由通道投影组合。

常用参数化令 $A_{i,i} = -\exp(a_i)$ 、 $\Delta_t = \text{softplus}(d_t)$ ，其中 a_i 是参数， d_t 由输入映射并加入偏置产生。这分别限制连续模式的衰减方向与步长的正值。 $\mathbf{B}_t$ 决定输入写入哪些状态坐标， $\mathbf{C}_t$ 决定本步从哪些坐标形成输出。离散化是模型定义的一部分，复现时需核对写入项采用的具体规则。

取标量特例 $A = -1$ 、 $B_t = 1$ 、 $D = 0$ ，更新成为

$$h^{(t)} = e^{-\Delta_t} h^{(t-1)} + (1 - e^{-\Delta_t}) x_t.\tag{10.50}$$

小步长主要保留旧状态，大步长更多采用当前输入。这与控制门有明确联系，但完整模块具有多个状态坐标及输入相关的读写映射，不能只用这个标量式代替模型。

10.6.4.2 完整模块的两条分支

选择性 SSM 只负责时间方向的状态计算。图 10.15 把它放回完整模块：输入归一化与投影后分成两条支路，一条经过短因果卷积和 SiLU，产生送入 SSM 的特征；另一条经过 SiLU 形成调制向量。SSM 输出与调制向量逐坐标相乘，再经过输出投影和残差相加。

令归一化输入为 $\tilde{\mathbf{x}}_t \in \mathbb{R}^d$ ，内部通道数为 d_{in} ，可将这两条支路写为

$$\begin{aligned}\mathbf{v}_t &= \text{SiLU}(\text{CausalConv}(\mathbf{W}_v \tilde{\mathbf{x}})_t), \\ \mathbf{z}_t &= \text{SiLU}(\mathbf{W}_z \tilde{\mathbf{x}}_t), \\ \mathbf{y}_t &= \text{SelectiveSSM}(\mathbf{v}_{1:t}), \\ \mathbf{u}_t &= \mathbf{x}_t + \mathbf{W}_{\text{out}}(\mathbf{y}_t \odot \mathbf{z}_t).\end{aligned}\tag{10.51}$$

¹⁹ A. Gu, T. Dao, *Mamba: Linear-Time Sequence Modeling with Selective State Spaces* In arXiv preprint arXiv:2312.00752, 2023




图 10.15 原始 Mamba 模块的主要计算路径。红色粗分支强调选择性的来源：短卷积后的输入特征生成 Δ_t, B_t, C_t ，并据此调节 SSM 更新；另一路特征调制 SSM 输出，底部直达线完成跨层残差。 u_t 是模块输出，任务预测由后续网络读出。图中省略短卷积缓存、批次维和跨通道广播细节。

$W_v, W_z \in \mathbb{R}^{d_{in} \times d}$, $W_{out} \in \mathbb{R}^{d \times d_{in}}$ 。各通道的选择系数由 v_t 产生, y_t, z_t 均为内部通道向量。SiLU 调制支路不是限制到 $[0, 1]$ 的保留门；决定时间记忆的主要是 SSM 中的步长与状态参数。短卷积补充局部上下文，残差提供层方向的直达路径，各自作用不同。

10.6.4.3 扫描、学习与计算代价

输入相关系数使响应依赖具体输入和绝对位置，一般不能继续使用一个固定卷积核。不过，整段输入给定后，各步系数可先从输入计算；状态更新对旧状态仍是仿射的，对角结构又使组合便宜，所以能够使用式(10.34)的扫描。若系数还依赖尚未算出的旧状态，就不能直接套用这种预先形成各步变换的方式，这也是它与一般 LSTM / GRU 计算组织的差别。

硬件感知的选择性扫描把离散化与状态更新放在适当存储层次中计算，

避免在较慢存储中显式写出所有通道、所有位置的扩展状态；反向时可以重算中间量。扫描与重算改变计算顺序和存储策略，任务损失仍对同一递推求导。输入输出投影、短卷积、选择映射、状态参数与步长参数共同学习，选择哪些输入不是人工指定的必然结果。

设内部通道数为 d_{in} 、每通道状态宽度为 m ，状态更新工作量为 $O(Td_{\text{in}}m)$ ，逐步持久状态为 $O(d_{\text{in}}m)$ ，还需短卷积和移位缓存。通道投影另有每步 $O(dd_{\text{in}})$ 成本。定长预测状态与高效整段扫描降低了计算负担，训练仍需优化器状态和相应反向信息，不能仅按预测持久状态估算全部训练存储。

10.6.4.4 有效时间与长期保留

固定输入产生的系数，跨步状态扰动沿齐次路径传播为

$$\frac{\partial \mathbf{h}^{(t)}}{\partial \mathbf{h}^{(s)}} = \exp \left(\mathbf{A} \sum_{u=s+1}^t \Delta_u \right), \quad (10.52)$$

因为同一对角矩阵的指数可以相乘后合并。传播尺度由累计的内部步长决定：遇到无关输入时，若模型产生小 Δ_u ，经过很多位置也可以只积累较少衰减；需要更新时再加大步长，并通过 $\mathbf{B}_u$ 写入新内容。这将固定的逐步衰减变成内容相关的“有效经过时间”。

仍用式(10.50)作构造例子：从零状态读入 $x_1 = 1$ ，取 $\Delta_1 = \log 2$ ，得到 $h^{(1)} = 1/2$ 。其后 100 步输入为零且步长均为 0.001，末状态为 $(1/2)e^{-0.1} \approx 0.452$ 。这个例子展示小步长如何弱化中间位置的遗忘；真实任务还要学到哪些位置应如此处理，且写入项的大小同时受 $\mathbf{B}_t$ 和输入影响。

选择性并不等于显式保存每个历史位置。 $\mathbf{C}_t$ 读取的是压缩状态坐标，不能像逐位置注意力那样对任意过去表示重新评分；状态容量、输入干扰与有限精度仍限制可区分历史。系数对输入的导数、层间非线性和调制支路也进入完整梯度。选择机制提供了保留和覆盖的自由，扫描使这种机制便于计算，二者都不是无条件的长期检索保证。

10.6.5 RWKV

还可以用加权累积状态概括历史。**接收门加权键值网络** (receptance weighted key value, RWKV) 以时间混合和通道混合构成模块, 历史值由内容权重与时间衰减共同累积, 再由接收门控制输出。本节采用 2023 年论文中的 RWKV-4 形式; 后续版本的状态形状和更新可能不同²⁰。

10.6.5.1 时间混合与加权状态

设时间混合子模块的输入为 $\mathbf{x}_t \in \mathbb{R}^d$, 在完整层中它已由**层归一化** (layer normalization, LN) 得到。这里 LN 只对同一位置的 d 个特征坐标计算均值与方差, 标准化后再作可学习的逐坐标缩放和平移, 各位置共享这些参数; 具体公式见式(12.9)。它不跨样本或时间位置统计, 因此归一化本身不会读取未来输入。时间混合先在当前与前一步输入之间逐坐标混合, 再投影为键、值和接收向量:

$$\mathbf{a}_t = \mathbf{W}_a(\mu_a \odot \mathbf{x}_t + (\mathbf{1} - \mu_a) \odot \mathbf{x}_{t-1}), \quad \mathbf{a} \in \{\mathbf{k}, \mathbf{v}, \mathbf{r}\}. \quad (10.53)$$

其中 $\mu_a \in \mathbb{R}^d$ 是可学习混合系数, $\mathbf{W}_a \in \mathbb{R}^{d \times d}$; $\mathbf{k}_t, \mathbf{v}_t, \mathbf{r}_t$ 分别取 $\mathbf{a}_t$ 的对应结果。序列起始时的前一步输入需按约定初始化。

所有指数、除法和乘积按坐标进行。令非负衰减参数为 $\mathbf{w} \in \mathbb{R}^d$, 当前项偏置为 $\mathbf{u} \in \mathbb{R}^d$, 历史分子和分母状态初值为零, 则

$$\begin{aligned} \mathbf{v}_{\text{agg}}^{(t)} &= \frac{\mathbf{a}^{(t-1)} + e^{\mathbf{u} + \mathbf{k}_t} \odot \mathbf{v}_t}{\mathbf{b}^{(t-1)} + e^{\mathbf{u} + \mathbf{k}_t}}, \\ \mathbf{a}^{(t)} &= e^{-\mathbf{w}} \odot \mathbf{a}^{(t-1)} + e^{\mathbf{k}_t} \odot \mathbf{v}_t, \\ \mathbf{b}^{(t)} &= e^{-\mathbf{w}} \odot \mathbf{b}^{(t-1)} + e^{\mathbf{k}_t}, \\ \mathbf{o}_t &= \mathbf{W}_o(\text{sigmoid}(\mathbf{r}_t) \odot \mathbf{v}_{\text{agg}}^{(t)}). \end{aligned} \quad (10.54)$$

输出在历史状态更新前读取旧累积量, 并为当前项使用 $\mathbf{u}$; 之后写入状态的当前项不包含该偏置。展开分子可见, 第 $i < t$ 个位置的权重为 $\exp(-(t-1-i)\mathbf{w} + \mathbf{k}_i)$ 。它取决于该位置的键和时间距离, 接收门再决定每个通道输出多少, 没有对每个历史位置重新计算查询—键点积。

状态递推证明了过去加权和可以由两个向量维护, 不必逐步保存全部键值。直接指数形式容易上溢, 实际实现还维护尺度或最大值, 使用重缩放保持与上述比值等价。分母在非空步由正指数项保证为正; 不能把用于说明的直接公式当成任意数值范围下的稳定实现。

10.6.5.2 通道混合与完整残差层

时间混合负责历史累积, **通道混合** (channel mixing) 则在当前表示中组合不同特征。它也用当前与前一步输入作混合, 但不重复 WKV 的历史加

²⁰ B. Peng, E. Alcaide, Q. Anthony, A. Albalak, S. Arcadinho, S. Biderman, H. Cao, X. Cheng, M. Chung, L. Derczynski, X. Du, M. Grella, K. Gv, X. He, H. Hou, P. Kazienko, J. Kocon, J. Kong, B. Koptyra, H. Lau, J. Lin, K. S. I. Mantri, F. Mom, A. Saito, G. Song, X. Tang, J. Wind, S. Woźniak, Z. Zhang, Q. Zhou, J. Zhu, R.-J. Zhu, *RWKV: Reinventing RNNs for the Transformer Era* In Findings of the Association for Computational Linguistics: EMNLP 2023, 2023, pp. 14048–14077

权和。令相应子模块输入仍记为 $\mathbf{x}_t \in \mathbb{R}^d$ ，可写为

$$\begin{aligned} \mathbf{k}'_t &= \mathbf{W}'_k (\mu'_k \odot \mathbf{x}_t + (\mathbf{1} - \mu'_k) \odot \mathbf{x}_{t-1}), \\ \mathbf{r}'_t &= \mathbf{W}'_r (\mu'_r \odot \mathbf{x}_t + (\mathbf{1} - \mu'_r) \odot \mathbf{x}_{t-1}), \\ \mathbf{o}'_t &= \text{sigmoid}(\mathbf{r}'_t) \odot \mathbf{W}'_v (\text{ReLU}(\mathbf{k}'_t) \odot \text{ReLU}(\mathbf{k}'_t)). \end{aligned} \quad (10.55)$$

若内部宽度为 d_{ff} ，则 $\mathbf{W}'_k \in \mathbb{R}^{d_{\text{ff}} \times d}$ 、 $\mathbf{W}'_v \in \mathbb{R}^{d \times d_{\text{ff}}}$ 、 $\mathbf{W}'_r \in \mathbb{R}^{d \times d}$ 。平方 ReLU 提供非线性通道变换，接收门调节其输出。混合系数是可学习参数，若没有额外约束，不保证它们一直处于 $[0, 1]$ 。

图 10.16 先给出完整残差层，再用虚线把时间混合子模块 A 与其内部计算对应起来。下方的输出 $\mathbf{o}_t$ 就是上方 A 送入第一个残差加法的量；通道混合 B 随后处理更新的表示。在完整层公式中， $\mathbf{x}_t$ 改指归一化之前的层输入， $\mathbf{s}_t$ 表示第一次残差相加后的中间量，区别于 WKV 中的值向量 $\mathbf{v}_t$ 。典型的归一化与残差关系为

$$\begin{aligned} \mathbf{s}_t &= \mathbf{x}_t + \text{TimeMix}(\text{LN}_1(\mathbf{x}_t)), \\ \mathbf{u}_t &= \mathbf{s}_t + \text{ChannelMix}(\text{LN}_2(\mathbf{s}_t)). \end{aligned} \quad (10.56)$$

LN 是逐位置层归一化，状态更新在各子模块内部进行。时间混合与通道混合分别缓存自己的前一步输入，不能把二者简单共用为一份原始词元嵌入。完整生成网络在嵌入之后堆叠这些层，再用归一化和词表投影形成下一词元的概率。

训练时，各位置的稠密投影可以批量计算，WKV 核心仍处理有序累积；可使用顺序扫描，满足组合条件时也可采用并行前缀计算。投影、混合系数、衰减及门由任务损失共同更新。逐步预测则只延续累积、移位与数值尺度状态。按 d 个通道计，累积核心整段为 $O(Td)$ 、持久状态为 $O(d)$ ，稠密投影另有每步 $O(d^2)$ 或 $O(dd_{\text{ff}})$ 成本；层数、词表与训练反向信息需另外计算。

10.6.5.3 归一化权重与长期依赖

RWKV 没有在累积状态上反复施加普通 RNN 的稠密非线性变换，旧贡献沿各通道按 e^{-w_i} 保留。较小的 w_i 提供较长时间尺度，较大的值强调近期；内容键再改变各位置写入的权重。对固定键与衰减，某个历史值坐标对当前聚合的直接系数是归一化权重：

$$\frac{\partial v_{\text{agg},j}^{(t)}}{\partial v_{i,j}} = \frac{\exp(-(t-1-i)w_j + k_{i,j})}{b_j^{(t-1)} + \exp(u_j + k_{t,j})}, \quad i < t. \quad (10.57)$$

它取决于内容与时间距离，不是一个任意非线性状态雅可比的连乘。接收门、输出投影以及键的变化仍参与完整任务梯度，不能仅凭这个分支宣称




图 10.16 RWKV-4 的完整残差层与时间混合子模块。上方在 A、B 之前分别归一化，并在各子模块之后作残差相加，第一次相加得到 s_t 。下方只展开 A，无箭头虚线表示对应关系； $\tilde{x}_t = \text{LN}_1(x_t)$ 是归一化后的特征。红框给出未作数值重缩放时的简化递推，说明旧状态按 e^{-w} 衰减、当前键值按 e^{k_t} 写入；实际实现还维护分母状态。图中省略稳定化重缩放、移位缓存的保存箭头及 B 的内部计算。

没有梯度消失。

归一化约束了加权聚合的范围，却不取消遗忘。若 $w_j > 0$ ，早期权重仍会随距离指数减弱；即使 $w_j = 0$ 、所有键相同且当前偏置为零，单个位置的权重也会随位置数按 $1/t$ 稀释。较大内容权重可以让某些位置更突出，但并未建立对每个历史位置重新执行查询的机制。

压缩还会合并不同历史。例如只看一个 $w = 0$ 、全部键为零的累积核心，值序列 $(1, 0, 0)$ 与 $(0, 1, 0)$ 都产生分子 1、分母 3。它们的位置不同，两个累积量却相同；只依据这组状态无法区分证据曾出现在哪一步。多通道、移位和深层非线性增加了可用表示，但仍需依据具体任务检查压缩后的可区分性。

RWKV 因此用内容加权、可学习衰减和接收门组织可延续的历史，使训练投影便于批量计算、预测状态保持定长。它缓解了一部分普通非线性循环路径的困难，保留范围与检索能力仍由时间尺度、写入权重、层间计算和任务监督共同决定。

表 10.1 统一比较上述状态模块。HiPPO 是一套状态构造原则，S4、Mamba 和 RWKV 是利用特定结构组织序列计算的网路设计，不能仅按名称把它们当作同一层面的互斥分类。

模型或原则	历史表示与选择	整段计算	逐步持久状态
普通 RNN	非线性隐藏状态；全部坐标经共同更新	时间递推与 BPTT	单层 m 维状态
LSTM / GRU	门调节保留和写入；LSTM 另有记忆状态	通常逐步递推	等宽 LSTM 为 $2m$ ，GRU 为 m
HiPPO	基函数系数；测度与阶数决定近似范围	取决于所选更新与离散化	m 个投影系数
S4 Mamba	结构化线性状态；固定时间响应输入相关步长、写入与读出	LTI 模块可用结构核与 FFT 卷积选择性仿射扫描	每通道 m 维状态 d 通道共 dm 维状态，另有短卷积缓存
RWKV-4	内容加权累积、时间衰减与接收门	批量投影和加权扫描等	两组累积向量及移位、数值尺度缓存

表 10.1 历史压缩与计算方式的比较。这里 m 表示状态宽度， d 表示通道数，均按单层比较；持久状态只计流式预测中需延续的信息，不含参数、输出缓存和反向传播激活。稠密投影、层数与数值实现会改变完整网络的计算和存储。

定长状态的代价不随已读长度线性增加，但相同宽度并不意味着相同的信息容量。循环注意力保存各位置编码状态，付出随输入长度增长的存储与读取；压缩状态把这一要求转为历史如何概括。两类模型的取舍应结合任务所需的精确位置访问、预测延迟和输入范围判断。

10.7 循环神经网络的扩展

此前主要沿一条时间链组织状态。实际任务还会改变两个方向：信息可以沿不同拓扑传递，同一位置也可以经过多层表示变换。前者决定一个状态

看得到哪些对象，后者决定状态经过多少层计算，两者应分开描述。

10.7.1 支持不同的拓扑结构

10.7.1.1 双向循环与信息可见范围

离线词语标注可以利用整段文字，单向状态却只看到当前位置及此前输入。**双向循环网络** (bidirectional RNN) 分别沿正向和反向读取同一输入，再把同一位置的两组状态组合：

$$\begin{aligned}\vec{h}^{(t)} &= F_{\rightarrow}(\vec{h}^{(t-1)}, \mathbf{x}_t), \\ \tilde{h}^{(t)} &= F_{\leftarrow}(\tilde{h}^{(t+1)}, \mathbf{x}_t), \\ \mathbf{h}_t &= [\vec{h}^{(t)}; \tilde{h}^{(t)}].\end{aligned}\quad (10.58)$$

双向通常使用不同参数，分别从序列两端的初态开始。反向上标 (t) 仍对齐输入位置，计算次序却是 $T, T-1, \dots, 1$ 。两条链在同一步不必互相反馈，组合后的表示交给读出或下一层。

双向表示能使用后文，前提是后文在预测时已经可见。实时下一步预测若把尚未到达的观测送入反向链，就泄漏了未来信息；整段编码器用于转换任务则可以合法读取完整源序列。结构是否可用取决于预测时的可见信息，而不是任务名称中是否含有“序列”。

10.7.1.2 多维与多方向循环

规则网格中的当前位置可以依赖多个已计算的邻居。**多维循环网络** (multi-dimensional RNN) 沿网格上的有向顺序组合这些前驱状态。例如二维网格的一个方向可采用

$$\mathbf{h}_{i,j} = \tanh(\mathbf{U}\mathbf{x}_{i,j} + \mathbf{W}_1\mathbf{h}_{i-1,j} + \mathbf{W}_2\mathbf{h}_{i,j-1} + \mathbf{b}). \quad (10.59)$$

网格边界上的缺失前驱按约定初始化。该方向只读取上方和左方已形成的表示；按 $i+j$ 分组时，同一对角线的节点可并行，而后续对角线依赖此前结果。再以其他角落为起点建立多个方向，就能组合不同象限的上下文²¹。

这里的多方向不是对同一条序列多跑几次，而是改变前驱关系。梯度沿多个前驱分支回传，对共享参数累积所有位置的贡献。直接把多路记忆相加还会增加状态幅度，门控、归一化和组合规则需随前驱数量设计；一维单元的稳定性不能不加条件地迁移过来。

²¹ A. Graves, S. Fernández, J. Schmidhuber, *Multi-Dimensional Recurrent Neural Networks* In arXiv preprint arXiv:0705.2011, 2007

10.7.1.3 树递归与 Tree-LSTM

当输入已有语法树或层次结构时，相邻叶子未必就是最自然的组合对象。

树递归网络（recursive neural network）按树的父子依赖组合状态：先得子节点表示，再在父节点生成更大子结构的表示。名称中的 recursive 描述结构递归，与沿时间重复更新的 recurrent 口径不同，本章把二者都放在隐状态递推的框架下比较。

二叉树可以把左右子状态拼接后变换；子节点数不固定时，可以先求和聚合。**树结构长短期记忆**（Tree-LSTM）为每个子节点设置遗忘门，以不同权重组合其记忆。以 Child-Sum 版本为例，令 $C(j)$ 是节点 j 的子节点索引集合， $\mathbf{x}_j$ 是本节点输入， $\mathbf{h}_j, \mathbf{c}_j$ 分别为隐藏和记忆状态，计算

$$\begin{aligned}
 \bar{\mathbf{h}}_j &= \sum_{k \in C(j)} \mathbf{h}_k, \\
 \mathbf{i}_j &= \text{sigmoid}(\mathbf{U}_i \mathbf{x}_j + \mathbf{W}_i \bar{\mathbf{h}}_j + \mathbf{b}_i), \\
 \mathbf{o}_j &= \text{sigmoid}(\mathbf{U}_o \mathbf{x}_j + \mathbf{W}_o \bar{\mathbf{h}}_j + \mathbf{b}_o), \\
 \tilde{\mathbf{c}}_j &= \tanh(\mathbf{U}_c \mathbf{x}_j + \mathbf{W}_c \bar{\mathbf{h}}_j + \mathbf{b}_c), \\
 \mathbf{f}_{j,k} &= \text{sigmoid}(\mathbf{U}_f \mathbf{x}_j + \mathbf{W}_f \mathbf{h}_k + \mathbf{b}_f), \quad k \in C(j), \\
 \mathbf{c}_j &= \mathbf{i}_j \odot \tilde{\mathbf{c}}_j + \sum_{k \in C(j)} \mathbf{f}_{j,k} \odot \mathbf{c}_k, \\
 \mathbf{h}_j &= \mathbf{o}_j \odot \tanh(\mathbf{c}_j).
 \end{aligned} \tag{10.60}$$

叶节点的空和为零，参数形状与等宽链式 LSTM 相同。求和对孩子的重编号不变，但会弱化孩子次序；若左右位置具有不同语义，采用带位置参数的有序树版本更合适。Tree-LSTM 的代表工作分别讨论了这两类结构²²。

图 10.17 将依赖范围与计算顺序并列展示。树上的反向传播从父节点回到各孩子，多个损失的贡献在同一节点汇合；共享组合参数的梯度再对所有节点累积。两个叶子经树组合到共同祖先的路径可以短于按词序遍历的路径，但这种优势依赖给定树是否符合任务，还增加了结构取得与处理的要求。

10.7.2 支持更深的网络

时间展开的深度由序列长度决定，同一位置的表示变换深度则由层数决定。增加层数既可以让任务学习更多表示变换，也可以仅堆叠固定动态、提供更多历史特征。二者共享层次结构，却训练不同参数。

²² K. S. Tai, R. Socher, C. D. Manning, *Improved Semantic Representations From Tree-Structured Long Short-Term Memory Networks* In Proceedings of the 53rd Annual Meeting of the Association for Computational Linguistics and the 7th International Joint Conference on Natural Language Processing, 2015, pp. 1556–1566




图 10.17 状态依赖拓扑。左图在同一输入位置组合正向与反向状态；中图由上方、左方前驱形成二维状态，箭头给出一个扫描方向；右图由叶节点向父节点组合子结构。红色表示隐藏计算，黄色节点表示组合读出。图中只表达依赖关系；不同方向、位置或孩子组合是否共享参数，需要由具体模型说明。

10.7.2.1 堆叠循环网络：学习各层表示与时间动态

堆叠循环网络 (stacked RNN) 让上层读取下层在相同位置的状态，同时维护自己的历史。设层数为 L ， $\mathbf{h}_0^{(t)} = \mathbf{x}_t$ ，则

$$\mathbf{h}_\ell^{(t)} = F_\ell(\mathbf{h}_\ell^{(t-1)}, \mathbf{h}_{\ell-1}^{(t)}), \quad \ell = 1, \dots, L. \quad (10.61)$$

上标是时间步，下标 ℓ 是层索引。同一层跨步共享参数，不同层通常各用一组参数。单元可选普通 RNN、LSTM 或 GRU；使用 LSTM 时，各层还维护自己的记忆状态 $\mathbf{c}_\ell^{(t)}$ 。

第 t 步先计算底层，再把底层当前表示送到第二层，依次形成顶层表示。因而第二层同时读取“这一位置的底层特征”与“第二层此前形成的历史”，不是只把整段底层末状态当作第二层的单个输入。单向堆叠仍只使用当前及此前输入；增加层数不会自动获得未来信息。

任务损失通常从顶层读出，也可以拼接或加权读取多个层。训练时梯度既沿时间回传，也沿层间依赖回传，各层循环与输入映射都接受任务监督。下层可以形成较局部的表示，上层再组合这些表示，但不同层对应的时间尺度应从实际动态或任务行为中检验，不能仅按层号断言上层必然记得更久。

若第 ℓ 层宽度为 m_ℓ 、 $m_0 = d$ ，普通稠密单元的整段计算量级为

$$O\left(T \sum_{\ell=1}^L m_\ell (m_{\ell-1} + m_\ell)\right), \quad (10.62)$$

门控单元还增加相应常数。完整反向计算需保存或重算各层各步的激活。层宽、读出范围与训练存储因此都影响深度选择。

10.7.2.2 深度储备池计算：堆叠固定动态、学习统一读出

深度储备池计算（deep reservoir computing）把多个通常固定的储备池按层连接，利用层层动态形成历史特征，再训练任务读出。深度 ESN 是代表形式，第一层读取外部输入，上层读取下层当前状态²³。

对泄漏积分单元，可写为

$$\begin{aligned} \mathbf{h}_\ell^{(t)} &= (1 - \alpha_\ell) \mathbf{h}_\ell^{(t-1)} + \alpha_\ell \tanh(\mathbf{W}_\ell \mathbf{h}_\ell^{(t-1)} + \mathbf{U}_\ell \mathbf{h}_{\ell-1}^{(t)} + \mathbf{b}_\ell), \\ \hat{\mathbf{y}}_t &= g(\mathbf{V}[1; \mathbf{x}_t; \mathbf{h}_1^{(t)}; \dots; \mathbf{h}_L^{(t)}]). \end{aligned} \quad (10.63)$$

$0 < \alpha_\ell \leq 1$ 是各层泄漏率， $\mathbf{W}_\ell, \mathbf{U}_\ell, \mathbf{b}_\ell$ 按构造固定， $\mathbf{V}$ 是可训练读出矩阵；也可以只读部分层。训练先逐步收集拼接特征，再拟合读出，平方损失时仍是一组扩展特征上的岭回归，不需要为固定循环参数执行任务梯度更新。

层叠改变输入经过的动态过滤。在线性标量简化且循环矩阵为零时， $h^{(t)} = (1 - \alpha)h^{(t-1)} + \alpha u_t$ ，记忆按 $(1 - \alpha)^k$ 衰减，对 $0 < \alpha < 1$ 的时间尺度为 $-1/\log(1 - \alpha)$ 。这说明不同泄漏率可以提供不同更新速度；真实储备池还包含反馈矩阵、输入驱动与非线性，不能只用泄漏率给整个模型确定唯一记忆长度。

各层也要检查回声状态性质。设相同输入下的两条轨迹距离为 $\delta_\ell^{(t)}$ ，Tanh 的 Lipschitz 性质给出

$$\delta_\ell^{(t)} \leq r_\ell \delta_\ell^{(t-1)} + \alpha_\ell \|\mathbf{U}_\ell\|_2 \delta_{\ell-1}^{(t)}, \quad r_\ell = 1 - \alpha_\ell + \alpha_\ell \|\mathbf{W}_\ell\|_2. \quad (10.64)$$

外部输入相同时 $\delta_0^{(t)} = 0$ 。有限层数、各 $r_\ell < 1$ 且层间映射有界时，下层初态差异逐渐消失，上层受其驱动的差异也能衰减。这是充分条件；仅检查某一层或仅按谱半径缩放全部矩阵，不能代替完整层间动态分析。

与可训练堆叠 RNN 相比，深度储备池减少了循环动态的优化范围，多个层的特征可供同一读出选择；代价是固定状态变换不能按任务梯度重新安排记忆。层数、宽度、连接尺度和泄漏率通常由验证过程选择，测试数据不能参与这种选择。更多固定层可能增加有用时间特征，也可能增加冗余或压缩损失，需要与浅层储备池在相近预算下比较。

10.7.2.3 跨层连接与分层读出

可训练网络与固定储备池都可以改变层间连接。维度相同时，跨层残差可写为 $\mathbf{u}_\ell^{(t)} = \mathbf{h}_{\ell-1}^{(t)} + \mathbf{G}_\ell^{(t)}$ ，其中 $\mathbf{G}_\ell^{(t)}$ 是这一层产生的变换结果；维度不同时先投影直达分支。残差为层方向提供较直接的梯度路径，通常没有缩短同一层的时间路径。

分层读出把不同层的状态送到任务头，使监督或读出可以直接使用多

²³ C. Gallicchio, A. Micheli, L. Pedrelli, *Design of Deep Echo State Networks In Neural Networks*, 2018, vol. 108, pp. 33–47

个层次的特征；它扩大了读出输入与参数规模。跨时间跳跃、跨层残差和门控可以组合，但应逐条注明连接哪些状态、训练哪些参数。层深、时间尺度与读出范围共同决定表示组织，“更深”不能单独推出“记得更久”。

10.8 理论分析

结构提供了可用的信息路径，仍需考察学习能否改进目标，以及有限训练数据能否支持新序列上的预测。以下分别分析参数优化与预测风险，承接机器学习理论部分的工具；状态递推是否稳定作为影响条件出现，不与参数优化的收敛混为一谈。

10.8.1 收敛性

有界状态不等于训练会收敛。Tanh 保证每个隐藏坐标有界，但状态对参数的导数仍包含多步雅可比乘积。反过来，训练目标下降也不保证输入流上的状态趋于一个常值：持续变化的输入本就可能需要持续变化的状态。

对固定训练集、有限长度序列和确定的初始化规则，完整 BPTT 给出训练目标 $L(\theta)$ 的精确梯度。假设在迭代所处区域内 L 可微、梯度为 β -Lipschitz 且 $L \geq L_{\inf}$ ，用步长 $0 < \eta \leq 1/\beta$ 更新。下降引理给出

$$L(\theta^{(k+1)}) \leq L(\theta^{(k)}) - \frac{\eta}{2} \|\nabla L(\theta^{(k)})\|_2^2, \quad (10.65)$$

这里 (k) 是参数更新轮次，与状态时间步 (t) 分开。将 K 次不等式相加得到

$$\frac{1}{K} \sum_{k=0}^{K-1} \|\nabla L(\theta^{(k)})\|_2^2 \leq \frac{2(L(\theta^{(0)}) - L_{\inf})}{\eta K}. \quad (10.66)$$

这个结论保证平均平方梯度随迭代次数变小，涉及趋近一阶驻点；它没有保证找到全局最优参数，也没有保证参数序列本身收敛。非光滑激活、随机梯度、裁剪或自适应优化需使用各自的分析条件，不能直接套用这条确定性结论。

循环结构会改变假设中的常数。状态对参数的一阶、二阶敏感度包含跨步传播，长序列与放大动态可能使允许的步长变小。较小梯度也可能来自早期路径消失，而不是目标已经满意；因此，梯度范数与训练误差需要同时解释。正交约束作用于线性部分，门控提供选择性路径，跳跃连接改变传播距离，但都不能单独保证完整非凸训练的全局收敛。

截断 BPTT 还改变了梯度对象。将所用梯度写成 $\tilde{g} = \nabla L + e$ ，误差 e 进入下降项 $\langle \nabla L, \tilde{g} \rangle$ ，因而式(10.65)不再自动成立。若跨步状态雅可比统一收缩且局部导数有界，被切断的远期贡献可由几何尾和控制；当长期保留的路径接近不衰减时，短截断就可能遗漏显著贡献。

这种遗漏不只是代价分析中的常数。若某参数只在首步读入证据时起作用，损失仅在很晚的末步出现，把中间状态断开后，该参数对当前片段损失的梯度可以为零，而完整梯度仍非零。前向状态记住证据，并不能替代跨边界的信用分配。

储备池把循环参数固定后，平方损失读出可转为式(10.15)的凸二次问题。 $\lambda > 0$ 时该问题具有唯一解，可以直接求解，也可以在适当步长下迭代。这个结论只覆盖给定状态特征的读出优化，不覆盖储备池超参数选择或整个模型的预测质量。结构化状态网络同样需要区分可高效计算梯度与优化目标具有何种收敛保证。

10.8.2 泛化能力

先明确一个训练样本是什么。对独立评论分类，可以把整段评论及标签视为一个样本；对多个独立设备的数据流，也可以把每条按约定长度取得的序列视为样本。一个序列中有 T 个位置，不代表有 T 个独立训练样本。若只是同一条长流的重叠窗口，样本间相关，独立同分布结论需要相应依赖分析后才能使用。

设 $\mathcal{F}$ 是限定结构、参数范围和输入长度后的预测函数族， $\mathbf{Z}_1, \dots, \mathbf{Z}_n$ 为独立同分布的完整序列样本； $\mathbf{Z}$ 包含输入及相应目标。记有界损失为 $\ell(f, \mathbf{Z}) \in [0, 1]$ ，风险为 $R(f) = \mathbb{E}[\ell(f, \mathbf{Z})]$ ，经验风险为 $\hat{R}_n(f) = n^{-1} \sum_i \ell(f, \mathbf{Z}_i)$ 。对预先固定的有限候选族，Hoeffding 不等式与并合界给出，以至少 $1 - \delta$ 的概率，

$$\sup_{f \in \mathcal{F}} |R(f) - \hat{R}_n(f)| \leq \sqrt{\frac{\log(2|\mathcal{F}|/\delta)}{2n}}。 \quad (10.67)$$

统一界允许模型依据这些训练样本从候选中选择； n 仍是独立序列数。无界交叉熵不满足这里的 $[0, 1]$ 条件，需另加预测概率下界、截断损失或尾部条件，不能直接声称所有训练损失都受这个界控制。

连续参数族不能仅把参数数目填进 $|\mathcal{F}|$ 。可以使用覆盖数、Rademacher 复杂度或算法稳定性，具体依赖由任务和约束决定。若在全局允许样本上有一个有限的损失 ε -覆盖，式(10.67)可用于覆盖代表，并增加至多 2ε 的近似项。覆盖规模取决于参数范围及参数变化对输出的影响，循环敏感度由此进入泛化分析。

输入尺度和长度怎样影响敏感度，可以在普通单元上直接计算。假设初态为零、 $\|\mathbf{x}_t\|_2 \leq B_x$ ，激活为 1-Lipschitz 且零点取零， $\|\mathbf{W}\|_2 \leq r$ ，则

$$\|\mathbf{h}^{(t)}\|_2 \leq (\|\mathbf{U}\|_2 B_x + \|\mathbf{b}\|_2) \sum_{k=0}^{t-1} r^k。 \quad (10.68)$$

$r < 1$ 时几何和有统一上界, $r = 1$ 时按 t 增长, $r > 1$ 时该上界可能快速增长。对 Tanh 还可使用 $\sqrt{m}$ 的状态上界, 取较紧者; 状态有界却不意味着参数敏感度同样有界。

固定参数并扰动输入, 由逐步 Lipschitz 性质还能得到

$$\|\mathbf{h}^{(T)} - \tilde{\mathbf{h}}^{(T)}\|_2 \leq \|\mathbf{U}\|_2 \sum_{t=1}^T r^{T-t} \|\mathbf{x}_t - \tilde{\mathbf{x}}_t\|_2, \quad (10.69)$$

其中两条序列初态相同。读出再乘以输出映射和损失的相应 Lipschitz 常数。它解释了状态转移范数、输入尺度和长度为何需要进入分析, 却只是敏感度控制, 不能由 $r > 1$ 的松上界断言实际泛化必然较差。

结构也影响允许的函数族。隐状态维度、层数、双向或树状连接、门的参数, 以及注意力的评分与读取范围, 都会改变复杂度和信息约束。参数共享使参数数目不随长度增加, 但共享参数在更长计算中的重复作用仍可能改变复杂度常数。注意力权重归一化约束了固定值向量的聚合范围, 评分和编码表示的学习敏感度仍需计入; 结构化状态更新减少某些自由度, 也可能引入不符合数据的记忆假设。

长度外推 (length extrapolation) 考察测试序列超出训练长度范围时的预测。共享参数使网络能够运行在更长输入上, 却没有保证其误差保持不变。训练中未见的依赖距离、计数规模、时间尺度和状态饱和都可能改变行为。固定维度的实数状态在无限精度的数学模型中与有限精度实现也不同, 不能仅凭状态维度推出无限记忆, 或在没有精度假设时断言所有历史存储的绝对上限。

因此, 泛化比较应固定预测任务、数据来源、独立样本单位、长度范围和参数预算。训练长度内的测试误差、跨长度表现与跨分布表现是不同问题; 某一模型在一种序列任务上的优势, 不能自动转移为另一种任务中的一般保证。

10.9 常见应用

应用中的关键是把可见输入、输出含义、训练目标和预测时的状态延续对应起来。以下使用简单任务展示这一过程, 具体语言、信号和生成方法留给应用卷。

10.9.1 序列分类

以评论情感分类为例, 一个样本是整段评论和类别 y 。沿用第 10.2.1.3 节的嵌入查表方式, 将离散词元映射为 $\mathbf{x}_t = \mathbf{E}_{:,v_t}$, 其中 $\mathbf{E} \in \mathbb{R}^{d \times K_{\text{vocab}}}$, v_t 是词表索引, 再用 RNN、LSTM 或 GRU 编码。末状态或掩码平均形成整段表示, 经 Softmax 分类头输出概率, 训练时对独立评论的交叉熵取平均; 嵌

入、循环单元和分类头共同更新。

单向编码适合边读边更新状态，但如果目标是整段类别，预测仍需说明何时决定结果。双向编码在读到完整评论后利用前后上下文；使用末位置的双向状态时，不应误以为两向末位置都概括了全段，可分别取正向有效末状态与反向有效首状态，或聚合每个位置的双向表示。评估时保持分词、有效长度和聚合规则一致。

评论中的“并不精彩”提示模型需要组合否定与后续词，而不是只累计正向词频。这个例子说明状态有用的任务原因，不预设某个模型已经学会语言规则。应另留验证样本选择宽度、聚合与停止轮次，再用未参与这些选择的测试样本评价。

10.9.2 序列标注与时间预测

词语标注把每个有效位置的表示送入分类头，按照式(10.4)计算交叉熵。离线标注可用双向上下文，流式标注只使用当前已可见输入，或明确约定等待若干后续位置的延迟。逐位置 Softmax 没有显式约束标签之间的合法组合；如果需要这种约束，应增加相应输出模型，而不能认为循环隐藏状态已经等同于标签结构建模。

以设备温度预测为例， $\mathbf{x}_t$ 可包含当前温度、控制量和已知时间间隔，读完这一步后输出下一时刻的温度估计 $\hat{x}_{t+1}$ 。有效预测位置集合记为 V ，平方目标为

$$\ell = \frac{1}{|V|} \sum_{t \in V} (\hat{x}_{t+1} - x_{t+1})^2. \quad (10.70)$$

目标位移必须在构造样本时完成，预测时不能输入待预测值。归一化统计只从训练数据估计，划分沿实际预测时间或按独立设备进行，避免重叠窗口把同一未来观测泄漏到训练与测试两侧。

流式使用时，传入新观测、更新状态、输出预测，再等待下一观测。跨片段可以延续同一设备状态，训练中则按截断长度切断梯度；设备切换、重新启动或大段缺失后的重置规则需要与训练匹配。多步预测若反馈自己生成的数值，误差可能累积；若使用未来外部变量，只能输入预测时确已知道的部分。历史记忆不能弥补未来条件未知造成的信息缺口。

10.9.3 序列转换与生成

转换任务给定源序列，生成另一段目标序列。训练流程是编码源输入，给解码器输入 BOS 和真实目标前缀，以包含 EOS 的目标计算式(10.6)，再联合更新全部模块。带注意力时，同时保留有效编码状态及掩码，供各解码步读取。

预测流程中，源编码只需执行一次。解码器从初始状态和 BOS 开始，输

出一个条件分布，按约定策略选择符号，将该符号嵌入送入下一步；遇到 EOS 或预设最大长度停止。最大长度是计算与输出约束，不能把被截断的结果计为模型自然学会了终止。束搜索需要为不同候选分别维护解码状态，不能将多个前缀错误地共用一份可变状态。

单序列生成也可采用**自回归模型**（autoregressive model）：按已有前缀预测下一个符号，再把生成结果反馈为后续输入。源条件可省略或由其他输入提供，循环更新、教师强制和停止条件仍需明确。每步选择最大概率符号不等于整段最优，采样产生的多样性也不等于分布已经可靠；生成评价应对应实际使用的解码策略。

10.10 本章小结

输入陆续到达时，隐状态把此前计算带到当前，参数共享让同一更新规则适应不同长度。状态保留了什么，由更新、读出和任务监督共同决定。普通 RNN 将这套关系写成非线性递推，时间展开使梯度可以计算，也暴露了跨多步雅可比乘积对长期学习的限制。

围绕同一历史依赖问题，储备池把动态构造与读出学习分开，控制门选择保留和写入，注意力通过保存各位置表示扩大可读取的信息。状态空间路线则利用可组合的状态更新，把部分整段计算改写为卷积或扫描。它们分别改变可训练参数、信息通路和计算形式，常可组合使用；低预测存储量、良好梯度路径与充分记忆并不是同一个性质。

拓扑决定预测时可见哪些输入，深度决定各位置经历怎样的表示变换。双向和多方向读取需要相应输入已经可见，树递归需要给定结构；跨层连接的作用也应与跨时间路径分清。优化下降的条件、独立序列样本数、输入尺度和训练长度范围共同约束学习结论，能执行更长递推不等于已经具备长度外推能力。

把这些模型用于具体任务时，需同时确定输入编码、监督位置、输出概率或数值含义，以及状态何时延续和重置。这样才能回答章首的问题：历史不是因为网络名中含有“循环”就被充分利用，而是经由明确的状态表示和读取机制影响预测，并在适当的学习与数据条件下得到检验。

图神经网络

一个分子可以有不同数量的原子，每个原子连接的化学键也不一样；一篇论文的分类除了取决于正文，还可能与它引用的论文有关。这些输入既没有图像中整齐的网格，也没有序列中唯一的先后次序。若把对象按编号拼成向量，同一分子只需换一种原子编号，网络就会读到另一个输入；若只对每个对象单独使用前馈网络，又会丢掉连接关系。本章要回答的问题是：网络怎样利用不规则的关系形成表示，同时让预测遵守对象重编号及任务本身的对称性？

这个问题需要同时考察计算规则和信息范围。节点从哪些邻居读取信息、怎样把数量可变的输入组合起来，决定一轮计算；传播多少轮、是否反复使用同一组参数，决定关系影响能够传多远。关系的类型、变化时间和几何含义又会约束消息的形式。我们从共同的消息传递结构出发，比较不同图卷积与循环更新，再检查表示区分能力、传播行为和泛化条件，最后把这些选择接到具体预测任务中。

11.1 图神经网络概述

前馈网络可以处理预先提取的分子描述向量，但描述向量中包含什么关系，取决于特征设计。卷积网络共享一个窗口内的计算，依赖网格中明确的相对位置；一般关系网络没有统一的“左上邻居”。循环网络能够读取一串对象，却需要额外规定遍历次序。序列化和固定特征仍然可以用于图任务，只是这些表示需要另行解决关系保留、长度变化和编号敏感的问题。

图 (graph) 用节点表示对象，用边表示对象之间的关系，记为 $\mathcal{G} = (V, E)$ 。本章把节点编号为 $V = \{1, \dots, n\}$ ； $n = |V|$ 是节点数， $e = |E|$ 是边数。节点 i 的属性为 $\mathbf{x}_i \in \mathbb{R}^d$ ，边 $j \rightarrow i$ 的属性为 $\mathbf{a}_{i,j} \in \mathbb{R}^{d_e}$ 。这里先写接收节点 i ，再写发送节点 j ，便于与矩阵乘法对应。分子中的属性可包含原子种类和键类型，引用网络中的属性可包含论文内容；属性的存在不要求所有节点或所有边具有相同的原始信息格式。

邻接矩阵 (adjacency matrix) $\mathbf{A} \in \mathbb{R}^{n \times n}$ 记录连接， $\mathbf{A}_{i,j}$ 表示 $j \rightarrow i$ 的权重，无边时为零。**邻域** (neighborhood) $N(i) = \{j : \mathbf{A}_{i,j} \neq 0\}$ 是向 i 发送信

息的节点集合。在无向图上, $\mathbf{A} = \mathbf{A}^\top$, 一条边可以支持两个方向的消息; 在有向图上, 需要明确使用入边、出边还是同时使用两者。除特别说明外, 后文的谱域推导采用非负权重的无向图, 基础消息传递则允许有向边。

图神经网络 (graph neural network, GNN) 让网络沿给定关系交换并组合对象的表示。它把“谁与谁相连”变成计算的组织依据, 共享的更新规则则使同一网络可以处理不同节点数和邻居数。图在这里表示输入关系; 它不自动表示概率模型中的条件独立性, 也不意味着每条边都是因果关系。

编号只是保存节点的方式, 不能改变节点本身的含义。令 $\mathbf{X} \in \mathbb{R}^{n \times d}$ 按行存放节点特征, 即 $\mathbf{X}_{i,:} = \mathbf{x}_i^\top$; 用**置换矩阵** (permutation matrix) $\mathbf{P}$ 重新排列这些行, 则新的输入为 $\mathbf{X}' = \mathbf{P}\mathbf{X}$ 、 $\mathbf{A}' = \mathbf{P}\mathbf{A}\mathbf{P}^\top$, 边属性也须同步重排; **置换等变性** (permutation equivariance) 要求节点输出跟着节点一起重排; **置换不变性** (permutation invariance) 要求整图输出保持不变。不含边属性时, 两种要求可写为

$$\begin{aligned} F(\mathbf{P}\mathbf{A}\mathbf{P}^\top, \mathbf{P}\mathbf{X}) &= \mathbf{P}F(\mathbf{A}, \mathbf{X}), \\ f(\mathbf{P}\mathbf{A}\mathbf{P}^\top, \mathbf{P}\mathbf{X}) &= f(\mathbf{A}, \mathbf{X}). \end{aligned} \quad (11.1)$$

F 产生按节点排列的输出, f 产生整图输出。重编号后, 每个原子的预测仍对应同一个原子, 分子的属性预测仍对应同一个分子; 等变性并不要求不同原子的输出相同。

沿关系学习表示的思想早于今天的图卷积层。早期处理树和有向无环结构的递归网络, 沿既定依赖逐步形成表示; 一般图中的环却使“等邻居算完再计算自己”缺少自然终点。Gori 等在 2005 年提出图神经网络模型, 将节点状态定义为相互依赖方程的解, 允许直接处理带环的图, 并区分节点任务与整图任务¹。Scarselli 等在 2009 年的系统论述中, 以共享局部更新和收缩条件保证状态解唯一, 再通过反复更新求得稳定状态。这条路线的核心是让关系参与表示形成, 同时使带环依赖能够求值; 收缩条件也限制了可选的更新函数²。

另一条路线试图把卷积网络的共享滤波推广到不规则结构。Bruna 等在 2014 年的 Spectral CNN 中, 用图拉普拉斯的特征向量替代普通傅里叶模式, 在这些模式上学习滤波响应。它给出了图卷积的谱域定义, 但显式特征基带来计算成本和跨图使用的困难³。Defferrard 等在 2016 年以切比雪夫多项式实现谱滤波, 使计算转为有限邻域上的稀疏传播, 无需显式求出完整特征基。这里改变的不仅是计算速度: 多项式同时明确了滤波器能够读取多远的关系⁴。

到 2016 至 2017 年, 图上的有限轮次计算形成了几种不同设计。门控图网络用门控状态更新替代必须迭代至不动点的求值方式; GCN 把谱滤波的低阶近似改写为简单的归一化邻域层, 便于用节点标签端到端训练; GraphSAGE 通过采样与共享聚合, 为大图和未见节点组织计算。这些模

¹ M. Gori, G. Monfardini, F. Scarselli, *A New Model for Learning in Graph Domains* In Proceedings of the IEEE International Joint Conference on Neural Networks, 2005

² F. Scarselli, M. Gori, A. C. Tsoi, M. Hagenbuchner, G. Monfardini, *The Graph Neural Network Model* In IEEE Transactions on Neural Networks, 2009, vol. 20, no. 1, pp. 61–80

³ J. Bruna, W. Zaremba, A. Szlam, Y. LeCun, *Spectral Networks and Locally Connected Networks on Graphs* In International Conference on Learning Representations, 2014

⁴ M. Defferrard, X. Bresson, P. Vandergheynst, *Convolutional Neural Networks on Graphs with Fast Localized Spectral Filtering* In Advances in Neural Information Processing Systems, 2016

型分别改变了状态求值、传播算子和邻域读取方式，不是一条只靠增加层数的发展线索。后文将展开相应机制与条件。

这些设计又需要共同语言来比较。Gilmer 等在 2017 年把许多分子图模型概括为消息计算、状态更新和整图读出，使节点、边属性及参数共享的位置能够明确对照⁵。随后的问题从“能否沿边计算”转向“应保留哪些差别”：2018 年的 GAT 用内容决定邻居权重，2019 年的 GIN 联系邻域聚合与图结构区分能力。相关研究还将状态扩展到多种关系、随时间出现的事件及带几何坐标的对象，并分析传播过深时的信息损失。这些方向共同说明，图网络的发展既关心计算规模，也关心关系语义、对称性与表示能力。

因此，基础、卷积和循环图网络不是三套彼此隔绝的机制。基础结构回答如何沿边传递信息；卷积模型进一步规定传播算子；循环模型强调同一更新规则反复作用于状态。图的边可以形成环，但固定轮次展开后的计算图仍沿轮次前进，能够使用前面章节的反向传播。

⁵ J. Gilmer, S. S. Schoenholz, P. F. Riley, O. Vinyals, G. E. Dahl, *Neural Message Passing for Quantum Chemistry* In Proceedings of the 34th International Conference on Machine Learning, 2017, pp. 1263–1272

11.2 基础图神经网络

要让一个节点利用邻居，既要把邻居的属性变成可用信息，也要处理邻居数量不一致的问题。若把邻居按编号拼接，输入宽度会变化，计算还会依赖拼接次序。把各条边上的计算与邻域组合分开，可以同时解决这两个问题。

11.2.1 网络结构

消息传递 (message passing) 指每个节点沿边接收邻居提供的信息，再据此更新自身表示。消息是可学习的数值向量，不要求系统实际发送一条通信消息。用 $\mathbf{h}_i^{(l)} \in \mathbb{R}^m$ 表示节点 i 在第 l 轮之后的隐表示，初态可取 $\mathbf{h}_i^{(0)} = \phi_{\text{in}}(\mathbf{x}_i)$ 。一轮计算由三个步骤组成：

$$\begin{aligned} \mathbf{m}_{i \leftarrow j}^{(l)} &= M^{(l)}(\mathbf{h}_i^{(l)}, \mathbf{h}_j^{(l)}, \mathbf{a}_{i,j}), \\ \overline{\mathbf{m}}_i^{(l)} &= \text{AGG}^{(l)}(\{\mathbf{m}_{i \leftarrow j}^{(l)} : j \in N(i)\}), \\ \mathbf{h}_i^{(l+1)} &= U^{(l)}(\mathbf{h}_i^{(l)}, \overline{\mathbf{m}}_i^{(l)}). \end{aligned} \quad (11.2)$$

$M^{(l)}$ 是消息函数，输出固定维度的消息； $\text{AGG}^{(l)}$ 是聚合函数，把任意数量的消息组合成一个固定维度的向量； $U^{(l)}$ 是节点更新函数。双花括号表示**多重集** (multiset)：其中元素没有顺序，但重复出现的次数仍然有意义。两个邻居具有相同状态时，求和应计入两次，而不能因为数值相同就丢掉一个。

聚合通常选求和、平均或逐坐标最大值，也可以先计算权重再加权求和。空邻域上的求和取零；平均和最大值需要另约定空输入，例如取零并

提供空邻域标记。另一种做法是加入**自环** (self-loop), 使节点也向自身发送消息。自环是否与普通边共享参数取决于模型, 不能在已包含自身的更新中无说明地重复计入。

图 11.1 把节点 i 的一轮计算展开。各邻居先通过同一消息函数, 再进入对次序不敏感的聚合; 节点自己的旧表示另进入更新。这种分工既容纳边属性, 也保留自身与邻居信息的区别。




图 11.1 节点 i 的一轮消息传递。左侧蓝色节点 j, k, r 与红色节点 i 相连, 右侧分别计算三条消息, 再求和并更新 i 。上方路径把 i 的旧表示送入更新函数。图中省略消息函数对接收节点和边属性的额外输入, 所有节点使用相同的消息与更新规则。

在同一轮内, $M^{(l)}$ 和 $U^{(l)}$ 的参数在所有节点与边上共享。因此, 增加节点会增加计算量, 却不必增加参数量。若邻域聚合不依赖枚举次序, 输入编码和节点更新也使用共享函数, 就可按轮归纳证明式(11.1): 重编号只重排消息的接收位置, 聚合结果跟着重排, 更新后的表示也跟着重排。随机邻居采样还要求采样规则与编号无关; 不同随机抽样下输出数值未必一致, 等变性应针对对应的抽样或输出分布理解。

一轮只能读取直接邻居的旧表示。两轮之后, 邻居的表示已经包含它们的邻居, 节点因而可以利用两跳以内的信息。**图上的感受野** (graph receptive field) 就是能够经传播影响当前表示的节点范围; 在仅使用一跳邻域、没有全局通路时, L 轮的范围至多为 L 跳。图 11.2 强调更新的同步性: 必须读完上一轮再写下一轮, 不能把本轮刚更新的状态混入其他节点的同轮输入。

示例 11.1 两轮邻域平均 取无向路径 $1-2-3$, 初始标量为 $\mathbf{x} = (1, 0, 2)^\top$ 。为单独观察传播, 暂不使用可学习参数与非线性, 令

$$h_i^{(l+1)} = \frac{h_i^{(l)} + \sum_{j \in N(i)} h_j^{(l)}}{1 + |N(i)|}。$$




图 11.2 三节点路径上的同步传播。列顶的 $t = 0, 1, 2$ 表示同步快照，横向实线传递自身状态，斜线沿原图的相邻关系传递状态。红色粗线描出节点 3 经节点 2 影响节点 1 的两跳路径；同一列内没有即时传播，因此一次更新不能直接读取两跳之外的新信息。

一轮结果为 $(1/2, 1, 1)^T$ ，两轮结果为 $(3/4, 5/6, 1)^T$ 。节点 1 在第一轮没有读取节点 3，第二轮却通过节点 2 受到节点 3 的影响。这是人为构造的传播例子，不是训练所得的实验结果。

节点表示形成后，整图预测还需要**读出** (readout)：把数量可变的节点表示变成一个图表示。基本形式是

$$\mathbf{g} = \rho \left(\sum_{i \in V} \phi(\mathbf{h}_i^{(L)}) \right), \quad \hat{\mathbf{y}} = g_{\text{out}}(\mathbf{g}), \quad (11.3)$$

其中 ϕ 是共享的节点变换， ρ 是聚合后的变换。求和不因节点重排而改变，所以它把节点等变表示转为整图不变表示。平均会消去部分规模信息，最大值强调是否出现某类特征；若目标随对象数量累积，求和更符合这一结构假设，但仍需验证目标是否具有相应可加性。

只计固定宽度 m 下的稠密线性节点变换和线性消息，一轮常可组织为 $O(nm^2 + em)$ ：先对节点变换，再沿边聚合。若每条边都单独通过宽度为 m 的稠密网络，边计算可以达到 $O(em^2)$ 。因此，“图网络计算量随边数增长”需要同时说明消息函数和特征宽度。训练还要保存多轮激活；可变节点数不会自动带来固定的训练存储量。

11.2.2 输出和学习目标

预测对象可以是节点、节点对或整张图。三者可以共享同一个图编码器，但监督位置和样本组织不同。图 11.3 把这三种读出对应起来；损失仍按第 8.1.3 节所介绍的输出含义选择。




图 11.3 同一组节点表示的三种任务读出。蓝、黄、灰三个底色带分别承载节点、节点对和整图任务，分叉处直接标出 readout_1 、 $\text{readout}_{1,2}$ 与 readout_G 。节点预测读取一个节点，边或连接预测读取两个端点及可用的关系属性，整图预测先对全部节点作对称聚合；三个分支不要求在同一模型中同时启用。

节点分类在每个受监督节点上计算类别概率。设类别数为 C ，标签 $y_i \in \{1, \dots, C\}$ ，训练标签所在节点集合为 V_{train} ，则

$$\begin{aligned} p_i &= \text{softmax}(\mathbf{W}_{\text{out}} \mathbf{h}_i^{(L)} + \mathbf{b}_{\text{out}}), \\ L_{\text{node}} &= -\frac{1}{|V_{\text{train}}|} \sum_{i \in V_{\text{train}}} \log p_{i, y_i}. \end{aligned} \quad (11.4)$$

$\mathbf{W}_{\text{out}} \in \mathbb{R}^{C \times m_L}$ ， $\mathbf{b}_{\text{out}} \in \mathbb{R}^C$ 。其他节点可以按设定参与消息传递，但它们的标签不因此成为训练输入。标签掩码决定损失的位置，不能只把测试标签乘零后留在输入特征中。

边预测需要同时读取端点。设候选节点对集合为 B ，用成对读出函数计算得分，再变成存在连接的预测概率：

$$\begin{aligned} s_{i,j} &= g_{\text{pair}}(\mathbf{h}_i^{(L)}, \mathbf{h}_j^{(L)}, \mathbf{a}_{i,j}), \\ p_{i,j} &= \text{sigmoid}(s_{i,j}). \end{aligned}$$

对二值目标 $b_{i,j}$ 可使用

$$L_{\text{edge}} = -\frac{1}{|B|} \sum_{(i,j) \in B} [b_{i,j} \log p_{i,j} + (1 - b_{i,j}) \log(1 - p_{i,j})]. \quad (11.5)$$

未观察到的连接通常没有该边的属性，此时应省略属性或使用预测时可得候选关系类型。无向连接的评分需要满足 $s_{i,j} = s_{j,i}$ ，例如采用点积；有

向连接可以使用一般双线性评分或有序拼接，不能用对称评分表达任意方向差异。

整图预测把第 q 张图的读出 $\mathbf{g}_q$ 映射为类别或数值，按独立图样本平均损失。回归目标 $y_q \in \mathbb{R}$ 可写为

$$L_{\text{graph}} = \frac{1}{N} \sum_{q=1}^N \left(g_{\text{out}}(\mathbf{g}_q) - y_q \right)^2, \quad (11.6)$$

其中 N 是训练图数，各图的节点数 n_q 可以不同。按图平均给每张图相同权重；按全部节点平均会改变大图与小图的相对权重，二者对应不同的经验目标。

11.2.3 参数学习

11.2.3.1 沿消息通路回传梯度

固定 L 轮时，式(11.2)是有限的函数复合。前向沿边 $j \rightarrow i$ 读取节点 j 的状态，反向则计算这份状态对节点 i 的预测误差有多大影响，再把相应导数回到 j 。这条反向依赖不要求原图另有一条 $i \rightarrow j$ 的边；它来自前向计算的链式法则。图中的环已沿传播轮次展开，反向依次处理 $l = L - 1, \dots, 0$ ，不会在同一轮内无限绕圈。

用列向量 $\mathbf{g}_i^{(l)} = \partial L / \partial \mathbf{h}_i^{(l)} \in \mathbb{R}^{m_l}$ 记节点状态的总梯度。节点分类的输出头在受监督节点产生初始梯度；整图读出把整图损失回传到参与读出的节点；连接预测的评分头向两个端点回传。没有自身标签的节点也可能因影响其他节点的预测而得到梯度。下面暂设损失只经最终轮状态产生，若中间轮也有输出，须在该轮另加直接损失的导数。

一轮反向计算可以对应前向的三个环节。令消息宽度为 r_l ，聚合宽度为 $\bar{r}_l$ ，先将 $\mathbf{g}_i^{(l+1)}$ 经更新函数回到聚合向量，再经聚合回到各条消息：

$$\begin{aligned} \mathbf{v}_i^{(l)} &= \left(\frac{\partial U^{(l)}}{\partial \bar{\mathbf{m}}_i^{(l)}} \right)^{\top} \mathbf{g}_i^{(l+1)}, \\ \delta_{i \leftarrow j}^{(l)} &= \left(\frac{\partial \text{AGG}^{(l)}}{\partial \mathbf{m}_{i \leftarrow j}^{(l)}} \right)^{\top} \mathbf{v}_i^{(l)}. \end{aligned} \quad (11.7)$$

这里 $\mathbf{v}_i^{(l)} \in \mathbb{R}^{\bar{r}_l}$ ， $\delta_{i \leftarrow j}^{(l)} \in \mathbb{R}^{r_l}$ ；两个局部 Jacobian 矩阵的形状分别为 $m_{l+1} \times \bar{r}_l$ 和 $\bar{r}_l \times r_l$ 。所有导数都在前向保存的状态、消息及参数上计算。求和聚合的 Jacobian 是单位矩阵，所以每条消息收到同一个 $\mathbf{v}_i^{(l)}$ ；平均聚合再除以邻居数；逐坐标最大值把导数送到被选中的位置，平局处需约定次梯度或记录规则。内容相关加权还要对权重求导，不能只按固定加权和回传。

消息函数的两个状态输入会产生不同贡献。记 $\mathbf{J}_{1,i,j}^{(l)}$ 、 $\mathbf{J}_{2,i,j}^{(l)} \in \mathbb{R}^{r_l \times m_l}$ 分别为 $M^{(l)}$ 关于接收端状态和发送端状态的 Jacobian。节点 j 的总梯度为

$$\begin{aligned} \mathbf{g}_j^{(l)} = & \left(\frac{\partial U^{(l)}}{\partial \mathbf{h}_j^{(l)}} \right)^\top \mathbf{g}_j^{(l+1)} \\ & + \sum_{i: j \in N(i)} (\mathbf{J}_{2,i,j}^{(l)})^\top \delta_{i \leftarrow j} \\ & + \sum_{k \in N(j)} (\mathbf{J}_{1,j,k}^{(l)})^\top \delta_{j \leftarrow k} \end{aligned} \quad (11.8)$$

第一项经过 j 自身的更新分支，局部偏导把聚合输入暂视为固定；第二项汇总 j 向其他节点发送的消息，正是从各接收节点回到 j 的梯度；第三项来自 j 作为接收端参与消息计算的影响。若消息只依赖发送端，第三项为零。自环使同一状态同时充当两个输入，两个局部贡献都要计入；跨层连接也按其实际计算路径另行累加。

图 11.4 展示第二项的汇合。一个节点被多个接收节点读取时，每条读取路径都有一分导数，节点的总梯度是这些贡献的和。自动微分系统在计算图上完成这种累积；分布式实现若把相关计算放在不同设备上，则需要汇总同一状态和共享参数的贡献。




图 11.4 一份节点状态的梯度来自多条读取路径。(a) 只画前向分叉；(b) 单独跟踪一条接收路径的回传；(c) 同时回传两条路径，并在 $+$ 处累加为 $\mathbf{g}_j^{(l)}$ 。实线表示前向计算，红色虚线表示导数路径。图省略其他邻居的消息、接收节点自身的更新分支和任务输出头；反向依赖由前向读取决定，不要求原图存在反向边。

状态梯度继续传向上一轮，共享参数的梯度则汇集为本次优化器更新的输入。以一层线性消息 $\mathbf{m}_{i \leftarrow j} = \mathbf{W} \mathbf{h}_j$ 为例， $\mathbf{W} \in \mathbb{R}^{r_l \times m_l}$ ，接收端回传的消息梯度给发送端贡献 $\mathbf{W}^\top \delta_{i \leftarrow j}$ ，并给权重贡献一个外积。因此

$$\frac{\partial L}{\partial \mathbf{W}} = \sum_{(j \rightarrow i) \in E} \delta_{i \leftarrow j} \mathbf{h}_j^\top. \quad (11.9)$$

跨轮共享 $\mathbf{W}$ 时，还要对轮次求和。节点更新、输入编码及输出头中的共享参数使用同样规则，正则项的导数另加到相应参数。所有贡献计算完毕后才更新参数；边上的梯度不是每个节点各自修改一份独立权重。

示例 11.2 无标签节点怎样得到梯度 沿用示例 11.1 的两轮平均，只在节点 1 设置目标 0，取 $L = \frac{1}{2}(h_1^{(2)})^2$ 。此处状态与梯度都是标量，记 $g_i^{(l)} = \partial L / \partial h_i^{(l)}$ 。由 $h_1^{(2)} = 3/4$ ，最终轮梯度为 $(3/4, 0, 0)$ 。节点 1 的第二轮输出平均了上一轮节点 1 和 2 的状态，故

$$\mathbf{g}^{(1)} = (3/8, 3/8, 0)^\top, \quad \mathbf{g}^{(0)} = (5/16, 5/16, 1/8)^\top.$$

例如节点 3 没有标签，却通过节点 2 影响节点 1；它在初始轮收到的梯度为 $(3/8) \times (1/3) = 1/8$ 。这里没有可学习的传播参数，例子只核对状态导数。固定输入属性可以具有导数，但不会因此自动成为需要优化的参数。

11.2.3.2 训练批次与信息范围

全图训练 (full-graph training) 在每次前向计算中读取完整训练可见图，再在受监督位置计算损失。单图节点分类可以只抽取一批标签位置，却仍计算全图表示；它与只读取部分结构的训练不同。多个图可以通过块对角邻接矩阵组成一个不连通的大图批次，但读出必须保留各图的归属，不能把不同分子的节点一起求和。

大图上的 L 跳邻域可能迅速膨胀。**邻居采样** (neighbor sampling) 为本批目标节点逐层选择有限邻居，再在所需计算图上前向和反向。每层最多取 s 个邻居时，未经去重的展开规模可达到 $1 + s + \dots + s^L$ ；采样限制了每步分支数，却没有消除深度影响。均匀采样的均值可无偏估计一个固定邻域向量的平均，但非线性更新后的预测及其梯度通常不是全图结果的无偏估计，归一化和多层抽样还会进一步改变计算。

子图训练 (subgraph training) 抽取一部分节点及相应边，在这张子图中完成多轮传播。它便于多个目标共享计算，但截断边界改变了邻域。若希望保留目标节点完整的 L 跳计算，可以把外围节点作为上下文纳入；若只是使用诱导子图，就应说明采用了怎样的近似和归一化。采样误差、边界缺失和标签抽样是不同的变化来源。

数据的可见范围还取决于预测设定。**直推学习** (transductive learning) 针对训练时已知的一批对象预测未知标签：例如引用图的结构与全文特征可以全部可见，只在部分节点上提供标签。**归纳学习** (inductive learning) 要求把学到的规则用于此前没有见过的节点或图：训练阶段不能读取这些对象的未来信息。两种设定都可以使用共享消息函数；“参数与节点编号

无关”是结构性质,“模型对新对象表现可靠”仍是需要检验的泛化结论。

每次训练更新都应明确可见图、输入特征、监督集合和损失平均方式。对连接预测,还须在编码图中移除待评估的目标边及能直接暴露目标的副本;对动态预测,结构和属性只能来自预测时刻以前。这些限制由任务决定,不能通过只隐藏标签来替代。

11.2.3.3 参数更新与收敛条件

反向传播给出当前参数下的导数,优化器才决定怎样改变参数。将全部可学习参数记为 $\theta \in \mathbb{R}^p$, 固定数据与可见图,记训练损失加正则项为 $J(\theta)$ 。一次普通梯度更新为

$$\theta^{(t+1)} = \theta^{(t)} - \eta_t \hat{g}^{(t)}, \quad (11.10)$$

t 是优化器更新次数,与传播轮次 l 不同; $\eta_t > 0$ 是学习率。全目标求导时 $\hat{g}^{(t)} = \nabla J(\theta^{(t)})$, 抽批次时则是相应计算得到的梯度估计。每次更新都要在同一份参数下完成前向与反向,清空上一次梯度累积,再对本批贡献求和或按约定平均。

网络的多层复合、消息函数和输出头通常使 J 非凸。因而“训练收敛”需要明确指标:损失趋于稳定、梯度变小、参数趋于某一点和找到全局最小值是不同结论。图上使用共享参数或归一化,都不能单独保证最后一个结论。

一个有条件的结果说明梯度法为什么可能稳定降低目标。假定 J 有下界 $J_{\inf}$, 且梯度是 β -Lipschitz 的, 即 $\|\nabla J(\mathbf{u}) - \nabla J(\mathbf{v})\|_2 \leq \beta \|\mathbf{u} - \mathbf{v}\|_2$, 其中 $\beta > 0$ 。沿连接两参数的线段积分梯度, 可得

$$J(\mathbf{u}) \leq J(\mathbf{v}) + \langle \nabla J(\mathbf{v}), \mathbf{u} - \mathbf{v} \rangle + \frac{\beta}{2} \|\mathbf{u} - \mathbf{v}\|_2^2。$$

若使用完整梯度与固定学习率 $0 < \eta \leq 1/\beta$, 代入式(11.10)即得到

$$\begin{aligned} J(\theta^{(t+1)}) &\leq J(\theta^{(t)}) - \frac{\eta}{2} \|\nabla J(\theta^{(t)})\|_2^2, \\ \min_{0 \leq t < T} \|\nabla J(\theta^{(t)})\|_2^2 &\leq \frac{2[J(\theta^{(0)}) - J_{\inf}]}{\eta T}. \end{aligned} \quad (11.11)$$

第二行由第一行对 T 次更新求和得到, T 是优化步数。它保证存在梯度较小的迭代点; 在这些假设下完整序列的梯度范数也趋于零, 却不保证参数序列一定收敛, 更不把驻点变成全局最小值。ReLU 及最大聚合具有不可微位置, 任意图网络也未必有全局有限的 β , 所以不能未经核对便把这段光滑分析套到实际训练上。

抽样梯度还增加了波动。若它在给定参数下无偏、方差有统一上界, 并满足相应光滑性及下界条件, 递减学习率可以控制梯度噪声。经典条件包括 $\sum_t \eta_t = \infty$ 和 $\sum_t \eta_t^2 < \infty$, 能保证按学习率加权的期望梯度平方范数平

均值趋于零，仍不是参数或全局最优解的收敛保证。固定非零学习率通常只能保证平均梯度大小受噪声项控制，单步损失不必持续下降。Bottou 等的分析明确区分了这两种情形⁶。在固定编码图上，均匀抽取标签位置并按目标正确缩放，可以保持完整标签平均损失的无偏梯度；邻居采样经过多层非线性却未必如此。须先确定究竟在优化哪个目标，才能使用相应收敛结论；上述结论也不能自动推广到任意自适应优化器。

实际停止可结合最大步数、在固定评估计算上的训练损失与梯度范数，以及验证指标的早停。传播深度、初始化、度归一化、残差与门控会影响链式 Jacobian 的尺度，从而影响梯度过小或过大的程度；学习率和优化器也须与该尺度匹配。这些设计改善训练条件的可能性需要检验。固定参数下的状态迭代是否收敛则是另一问题，第 11.6.1.1 节讨论其充分条件；训练目标稳定也不能替代泛化检验。

⁶ L. Bottou, F. E. Curtis, J. Nocedal, *Optimization Methods for Large-Scale Machine Learning* In SIAM Review, 2018, vol. 60, no. 2, pp. 223–311

11.3 卷积图神经网络

第 9.2.1 节的离散卷积在每个位置使用同一组核系数。一维有限核可写为 $y_i = \sum_{r=-K}^K w_r x_{i-r}$ ：位置 i 改变时，系数 w_r 仍对应同一个相对偏移。图也需要共享关系上的计算，却通常没有统一的相对坐标。不同节点的邻居数不同，邻居没有自然次序，也没有一个可在整张图上反复移动的固定窗口。因此，不能直接把图节点编号代入 $i-r$ ；编号的差不表示关系距离。

图卷积 (graph convolution) 把规则网格上的共享滤波推广到图信号，即节点上的数值或特征。这个推广有两个互补入口。谱域保留经典卷积定理的形式：先把信号分解成模式，再对各模式的系数乘以滤波响应。空域保留共享局部组合的形式：沿图的邻域，用同一个消息规则计算贡献，再作不依赖邻居次序的聚合。一般图缺少普通平移，因而这里的“卷积”是图上的算子定义，不表示存在一个可以照搬的核翻转与窗口滑动过程。

一个线性图滤波器可以把两种入口联系起来。令 $Q \in \mathbb{R}^{n \times n}$ 是给定的局部传播矩阵，非对角非零元只位于相邻节点间；邻接矩阵就是一个选择。对 $H \in \mathbb{R}^{n \times d_{\text{in}}}$ ，可定义

$$Z = \sum_{k=0}^K Q^k H W_k, \quad W_k \in \mathbb{R}^{d_{\text{in}} \times d_{\text{out}}}. \quad (11.12)$$

其中 $Q^0 = I_n$ ， $Z \in \mathbb{R}^{n \times d_{\text{out}}}$ ； $k=0$ 处理自身， $k \geq 1$ 组织至多 k 跳内经传播到达的信息。 W_k 在所有节点共享，并不为每条具体路径另设参数。计算时递推 $H_0 = H$ 、 $H_k = QH_{k-1}$ ，累加 $H_k W_k$ ，无需显式形成通常更稠密的 Q^k 。非线性激活再作用于 Z ，多层这样的计算构成网络。

式(11.12)如何包含普通卷积，可以在周期的一维有向网格上看清。取移位矩阵 T ，满足 $(T\mathbf{x})_i = x_{i-1}$ ，下标按周期返回；则单通道有限核的循环

卷积是 $\sum_{r=-K}^K w_r T^r \mathbf{x}$ 。不同偏移对应重复移位或反向移位。一般图改用邻接或拉普拉斯等关系算子组织传播；无向图上的单个对称算子没有区分左右的标记，不能据此复原任意具有方向差别的网格卷积核。需要方向或关系类型时，应提供相应信息并使用不同关系算子。

共享还必须服从重编号。若 $\mathbf{Q}' = \mathbf{PQP}^\top$ 、 $\mathbf{H}' = \mathbf{PH}$ ，则 $\mathbf{Z}' = \mathbf{PZ}$ ，因为 $(\mathbf{PQP}^\top)^k \mathbf{P} = \mathbf{PQ}^k$ 。这使局部组合不依赖节点保存次序。但一般消息传递比线性卷积更广：注意力或非线性边消息可以让权重依赖输入，不必对应某个固定的线性频率响应。下面分别从图信号的模式与邻域计算定义具体算子，再比较两者的联系和适用条件。

11.3.1 谱域图神经网络

11.3.1.1 图拉普拉斯与图傅里叶变换

在规则网格上，傅里叶变换把信号分成不同变化速度的模式，卷积则对各模式调整幅度。一般图没有统一的平移，却仍能比较相连节点上的数值差异。对对称、非负的 $\mathbf{A}$ ，定义度 $d_i = \sum_j A_{i,j}$ 和度矩阵 $\mathbf{D} = \text{diag}(d_1, \dots, d_n)$ 。**图拉普拉斯矩阵** (graph Laplacian) $\mathbf{L}_c = \mathbf{D} - \mathbf{A}$ 把这些差异组织为线性算子：

$$\mathbf{x}^\top \mathbf{L}_c \mathbf{x} = \frac{1}{2} \sum_{i,j} A_{i,j} (x_i - x_j)^2. \quad (11.13)$$

右侧非负，所以 $\mathbf{L}_c$ 半正定。单位范数的向量若在相邻节点上变化小，能量就小；常量向量的能量为零。这给“图上的低频”提供了具体含义，而不需要预先把节点放在一条数轴上。

节点度差异较大时，常用**对称归一化拉普拉斯** (symmetric normalized Laplacian)。本节为简化推导，假定所有节点 $d_i > 0$ ，令

$$\mathbf{L} = \mathbf{I}_n - \mathbf{D}^{-1/2} \mathbf{A} \mathbf{D}^{-1/2} = \mathbf{U} \mathbf{\Lambda} \mathbf{U}^\top. \quad (11.14)$$

$\mathbf{U} \in \mathbb{R}^{n \times n}$ 的列 $\mathbf{u}_k$ 是正交特征向量， $\mathbf{\Lambda}$ 的对角元素 $\lambda_k \in [0, 2]$ 按升序排列。归一化后的能量比较 $x_i/\sqrt{d_i}$ 与 $x_j/\sqrt{d_j}$ ，因此零频模式在每个连通分量内与 $\sqrt{d_i}$ 成比例，未必是常量；不同分量可以具有不同的比例系数。图连通时，零特征空间才只有这一个方向。存在孤立节点时须另规定归一化约定，或加自环后再定义相应算子。

图傅里叶变换 (graph Fourier transform) 把节点上的信号改写为这些模式的系数： $\hat{\mathbf{x}} = \mathbf{U}^\top \mathbf{x}$ ，逆变换为 $\mathbf{x} = \mathbf{U} \hat{\mathbf{x}}$ 。给定频率响应 $g_\theta(\lambda)$ ，**谱滤波** (spectral filtering) 对每个系数乘以相应响应：

$$\mathbf{y} = \mathbf{U} g_\theta(\mathbf{\Lambda}) \mathbf{U}^\top \mathbf{x} = g_\theta(\mathbf{L}) \mathbf{x}. \quad (11.15)$$

图 11.5 显示这三步。谱域图卷积借用了经典卷积在傅里叶域逐频率相乘的

形式；一般图上的这一命名不保证它具有普通空间平移的含义。




图 11.5 谱滤波的计算路径。节点信号 x 经 U^T 分解为图傅里叶系数，每个模式由 $g_\theta(\lambda_k)$ 调整，再经 U 还原为节点信号。左、右两端使用同一张图和同一节点顺序；中间向量的下标表示频率模式。

示例 11.3 三节点路径上的低频模式 沿用路径 1-2-3，此处不加自环，度为 (1, 2, 1)。归一化拉普拉斯的特征值为 0, 1, 2，可取

$$\mathbf{u}_1 = \frac{1}{2}(1, \sqrt{2}, 1)^T, \quad \mathbf{u}_2 = \frac{1}{\sqrt{2}}(1, 0, -1)^T, \quad \mathbf{u}_3 = \frac{1}{2}(1, -\sqrt{2}, 1)^T.$$

输入 $x = (1, 0, 2)^T$ 的三个系数为 $3/2, -1/\sqrt{2}, 3/2$ 。若只保留零频模式，输出为 $(3/4, 3\sqrt{2}/4, 3/4)^T$ 。中间节点的数值较大，恰是度归一化后的平滑，而不是普通算术平均。

11.3.1.2 Spectral CNN：直接学习频率响应

Bruna 等的 Spectral CNN 把谱滤波放入多通道网络。对输入通道 a 与输出通道 b ，可以学习一个对角滤波器 $\Theta_{a,b}$ ，用 $U\Theta_{a,b}U^T$ 变换对应信号，再累加通道并使用非线性。完整谱上的自由响应需要每通道对 n 个参数；原工作还用少量样条系数插值得到平滑响应，减少参数自由度⁷。

固定图与傅里叶基时，前向计算是矩阵乘法，滤波参数可按链式法则求导。例如单通道 $y = U \text{diag}(\theta)\hat{x}$ ，上游梯度为 $v = \partial L / \partial y$ ，则 $\partial L / \partial \theta_k = (U^T v)_k \hat{x}_k$ 。通道与样本之间共享参数时，对相应贡献求和即可。

直接使用稠密 U 需要 $O(n^2)$ 的单信号变换和存储，完整稠密特征分解的常规代价为 $O(n^3)$ 。只保留部分特征向量可以改变代价，但也限制了可用模式。自由频率响应还可能对应全图稠密算子，不能仅凭“卷积”就认定它具有有限跳数的局部性。

对新图，特征值与特征向量都会变化，按旧图谱索引学习的自由系数没有自然的一一对应。特征向量的符号在 $U\Theta U^T$ 中相消，但重特征值对应的子空间还可以旋转；若该子空间内使用不同自由系数，算子就依赖具体基的选择。由同一个标量函数 $g(\lambda)$ 定义响应，能够消除这种基选择歧义；跨图迁移的预测效果仍需另行验证。

⁷J. Bruna, W. Zaremba, A. Szlam, Y. LeCun, *Spectral Networks and Locally Connected Networks on Graphs* In International Conference on Learning Representations, 2014

11.3.1.3 ChebNet: 用多项式实现局部滤波

若滤波器能够直接写成 $\mathbf{L}$ 的多项式, 就可以绕开显式傅里叶基。ChebNet 用切比雪夫多项式 (Chebyshev polynomial) 参数化响应。设 $\lambda_* > 0$ 是拉普拉斯谱的上界, 令 $\tilde{\mathbf{L}} = 2\mathbf{L}/\lambda_* - \mathbf{I}_n$, 把谱放到 $[-1, 1]$; 归一化拉普拉斯可取 $\lambda_* = 2$ 。约定 K 为最高次数, 则

$$g_\theta(\mathbf{L})\mathbf{x} = \sum_{k=0}^K \theta_k T_k(\tilde{\mathbf{L}})\mathbf{x}, \quad (11.16)$$

其中 $T_0(z) = 1$ 、 $T_1(z) = z$ 、 $T_k(z) = 2zT_{k-1}(z) - T_{k-2}(z)$ 。有些文献用 K 表示项数, 此时最高次数为 $K - 1$, 阅读时须核对约定⁸。

令 $\mathbf{z}_k = T_k(\tilde{\mathbf{L}})\mathbf{x}$, 即可用 $\mathbf{z}_0 = \mathbf{x}$ 、 $\mathbf{z}_1 = \tilde{\mathbf{L}}\mathbf{x}$ 以及 $\mathbf{z}_k = 2\tilde{\mathbf{L}}\mathbf{z}_{k-1} - \mathbf{z}_{k-2}$ 递推。整个过程只需要稀疏矩阵乘向量; 单通道的 $K \geq 1$ 阶计算量为 $O(K(n+e))$, 无需构造 $\mathbf{U}$ 。反向传播也经过这些稀疏乘法, 系数梯度为 $\mathbf{v}^\top \mathbf{z}_k$ 。

多项式为局局部, 可以从矩阵乘法看出。 $\mathbf{L}$ 的非对角非零元只连接相邻节点, 一次相乘至多走一条边; $\mathbf{L}^k$ 至多连接 k 跳以内。故式(11.16)在一层中读取至多 K 跳邻域。多通道形式为 $\mathbf{Y} = \sum_{k=0}^K T_k(\tilde{\mathbf{L}})\mathbf{X}\boldsymbol{\Theta}_k$, $\boldsymbol{\Theta}_k \in \mathbb{R}^{d_{\text{in}} \times d_{\text{out}}}$, 参数量为 $(K+1)d_{\text{in}}d_{\text{out}}$, 不随 n 增加。

这些系数描述同一个多项式, 所以可以在另一张图上重新构造拉普拉斯并使用它们, 无需对齐特征向量。相同计算规则能够运行在新图上, 并不保证新图具有相同的频率分布或任务关系。若使用的谱上界过小, 使缩放后的特征值落到 $[-1, 1]$ 以外, 高次多项式还可能迅速放大误差。

⁸ M. Defferrard, X. Bresson, P. Vandergheynst, *Convolutional Neural Networks on Graphs with Fast Localized Spectral Filtering* In Advances in Neural Information Processing Systems, 2016

11.3.2 空域图神经网络

空域方法直接回答节点怎样读取邻居。下面四种模型分别突出固定归一化、采样与分开组合、内容相关加权, 以及邻域多重集的区分能力。它们共享输出与反向传播的基础, 主要差别落在聚合和更新上。

11.3.2.1 GCN: 归一化的邻域传播

图卷积网络 (graph convolutional network, GCN) 在本节特指 Kipf 与 Welling 提出的层形式。加入自环 $\tilde{\mathbf{A}} = \mathbf{A} + \mathbf{I}_n$, 令 $\tilde{d}_i = \sum_j \tilde{A}_{i,j}$, 定义传播矩阵

$$\mathbf{S} = \tilde{\mathbf{D}}^{-1/2} \tilde{\mathbf{A}} \tilde{\mathbf{D}}^{-1/2}, \quad \mathbf{H}^{(l+1)} = \sigma(\mathbf{S} \mathbf{H}^{(l)} \mathbf{W}^{(l)}). \quad (11.17)$$

$\mathbf{H}^{(l)} \in \mathbb{R}^{n \times m_l}$ 按行存放状态, $\mathbf{H}^{(0)} = \mathbf{X}$; $\mathbf{W}^{(l)} \in \mathbb{R}^{m_l \times m_{l+1}}$ 变换特征通道, σ 逐坐标作用。采用行存放的矩阵形式时, 节点列向量的变换对应 $(\mathbf{W}^{(l)})^\top \mathbf{h}_i^{(l)}$ 。原始层式省略偏置, 增加共享偏置不会改变置换等变性。

从节点 j 到 i 的消息系数为 $\tilde{A}_{i,j}/\sqrt{\tilde{d}_i \tilde{d}_j}$, 同时计入边权以及接收端与发

送端的度。边权为 1 时，才简化为 $1/\sqrt{\tilde{d}_i \tilde{d}_j}$ 。它不是一般意义上的算术平均： $\mathbf{S}$ 的行和未必等于 1。沿用三节点无权路径与输入 $(1, 0, 2)^\top$ ，取单位特征变换和恒等激活，得到

$$\mathbf{S} = \begin{pmatrix} 1/2 & 1/\sqrt{6} & 0 \\ 1/\sqrt{6} & 1/3 & 1/\sqrt{6} \\ 0 & 1/\sqrt{6} & 1/2 \end{pmatrix}, \quad \mathbf{S}\mathbf{x} = \begin{pmatrix} 1/2 \\ 3/\sqrt{6} \\ 1 \end{pmatrix}. \quad (11.18)$$

这一结果与示例 11.1 的平均不同，差别来自归一化规则。

它与谱域方法的联系可以直接推导。对不加自环的归一化拉普拉斯，ChebNet 取 $K = 1$ 及 $\lambda_* = 2$ 时， $\tilde{\mathbf{L}} = -\mathbf{D}^{-1/2} \mathbf{A} \mathbf{D}^{-1/2}$ 。再约束 $\theta_0 = -\theta_1 = \theta$ ，得到 $\theta(\mathbf{I}_n + \mathbf{D}^{-1/2} \mathbf{A} \mathbf{D}^{-1/2})\mathbf{x}$ 。GCN 进一步以加自环后重新计算度的 $\mathbf{S}$ 替换括号内算子，限制反复传播的尺度。这一步是算子设计，不是二者恒等相等；原论文称其为重新归一化技巧⁹。

固定结构时，GCN 的梯度也可写清。记 $\mathbf{Z} = \mathbf{S}\mathbf{H}\mathbf{W}$ ， $\Delta = \partial L / \partial \mathbf{Z}$ ，则

$$\frac{\partial L}{\partial \mathbf{W}} = (\mathbf{S}\mathbf{H})^\top \Delta, \quad \frac{\partial L}{\partial \mathbf{H}} = \mathbf{S}^\top \Delta \mathbf{W}^\top. \quad (11.19)$$

激活的导数已并入 Δ 。不学习邻接关系时， $\mathbf{S}$ 作为给定算子；学习边权或建图规则时，才需进一步计算结构相关梯度。

标准 GCN 直接混合相邻节点的变换特征。相邻对象与预测目标相关时，这种共享聚合可以提供有用信息；相邻节点常具有不同标签或关系语义时，混合也可能损失区分所需的特征。模型仍可在新图上使用共享权重，归纳能力不由“GCN”或原论文的直推实验设定单独决定。

11.3.2.2 GraphSAGE：采样并学习邻域组合

在很大的图上，为一批目标节点计算全部邻域代价高；新节点到达后，也希望直接用属性及邻域产生表示。GraphSAGE 把采样与聚合纳入这一过程。以平均聚合为例，从 $N(i)$ 中取 $S_i^{(l)}$ ，令

$$\begin{aligned} \mathbf{u}_i^{(l)} &= \frac{1}{|S_i^{(l)}|} \sum_{j \in S_i^{(l)}} \mathbf{h}_j^{(l)}, \\ \mathbf{h}_i^{(l+1)} &= \sigma(\mathbf{W}^{(l)}[\mathbf{h}_i^{(l)}; \mathbf{u}_i^{(l)}] + \mathbf{b}^{(l)}). \end{aligned} \quad (11.20)$$

分号表示向量拼接，此处 $\mathbf{W}^{(l)} \in \mathbb{R}^{m_{l+1} \times 2m_l}$ 。自身和邻居先分开，再由不同的权重块组合；原算法还可对输出作 ℓ_2 归一化，零向量需要单独处理¹⁰。

聚合器也可对邻居先作共享前馈变换，再取逐坐标最大值。平均保留总体水平，最大池化突出某种响应是否出现。原论文还试验了对随机邻居顺序使用 LSTM 的聚合器；LSTM 本身依赖次序，随机打乱不能使一次确定

⁹ T. N. Kipf, M. Welling, *Semi-Supervised Classification with Graph Convolutional Networks* In International Conference on Learning Representations, 2017

¹⁰ W. L. Hamilton, R. Ying, J. Leskovec, *Inductive Representation Learning on Large Graphs* In Advances in Neural Information Processing Systems, 2017

性输出严格置换不变。需要严格对称性时，应选用对称聚合，或明确说明采用了怎样的对称化。

训练时采样所需邻域，计算节点或关系任务的损失，联合更新聚合器、组合矩阵及输出头。预测新节点时沿相同规则读取可用特征与邻域，不必为它单独学习一个节点编号嵌入。若新节点没有特征或可用邻居，模型仍受信息不足限制；若只把节点编号作为输入，所谓归纳流程也失去了可迁移的属性基础。

11.3.2.3 GAT：根据内容调整邻居权重

固定度归一化没有区分“邻居与当前任务是否相关”。**图注意力网络** (graph attention network, GAT) 用节点特征计算邻居权重，再在图约束的可见范围内加权聚合。对一个注意力头，令 $\mathbf{z}_i = \mathbf{W}\mathbf{h}_i$ ，其中 $\mathbf{W} \in \mathbb{R}^{m' \times m}$ ，则

$$\begin{aligned} e_{i,j} &= \text{LeakyReLU}(\mathbf{a}^\top [\mathbf{z}_i; \mathbf{z}_j]), \\ \alpha_{i,j} &= \frac{\exp(e_{i,j})}{\sum_{k \in N(i) \cup \{i\}} \exp(e_{i,k})}, \\ \mathbf{h}'_i &= \sigma \left(\sum_{j \in N(i) \cup \{i\}} \alpha_{i,j} \mathbf{z}_j \right). \end{aligned} \quad (11.21)$$

$\mathbf{a} \in \mathbb{R}^{2m'}$ 是共享评分参数； $e_{i,j}$ 是标量得分，与本章的边数 e 不同。Softmax 只在节点 i 的可见邻域内归一化，所有节点使用同一评分函数，所以邻居重排只重排对应权重¹¹。

多头注意力分别学习变换和评分，在隐藏层拼接结果，或在输出层取平均。训练时梯度同时通过值向量和权重；若把权重当作常量，就漏掉了评分函数对损失的影响。固定每头宽度时，增加头数还会增加总宽度和参数量，比较必须注明宽度预算。

与前章的循环注意力一样，GAT 把“计算权重”和“读取信息”分开；区别是可见位置由图的邻接关系约束。原始 GAT 的评分使用线性拼接，若将 $\mathbf{a}$ 拆成两部分，得分是单调激活作用于一个接收端项与一个发送端项之和。因此，在固定候选邻居特征下，邻居排序不能仅靠改变接收端特征任意翻转。内容相关权重并不意味着原始评分能够表达所有成对选择关系。

注意力可以重新分配已有邻居的影响，却不能一轮读取不在可见范围内的节点。权重归一化也不能保证这些权重等同于可靠的解释或因果贡献；输出仍由表示、评分、后续变换和训练共同决定。

11.3.2.4 GIN：保留邻域多重集的差别

聚合不仅影响尺度，还决定哪些输入差异会在计算中消失。例如邻域 $\{1, 1\}$ 与 $\{1, 1, 1\}$ 具有相同平均和最大值，但个数不同。另一个例子 $\{0, 2\}$ 与 $\{1, 1\}$

¹¹ P. Veličković, G. Cucurull, A. Casanova, A. Romero, P. Liò, Y. Bengio, *Graph Attention Networks* In International Conference on Learning Representations, 2018

连原始数值的和也相同；求和需要配合合适的特征映射，才能保留更多差别。图 11.6 展示第一种信息损失。




图 11.6 聚合如何保留或丢掉重复次数。两个邻域分别含两个和三个数值为 1 的邻居。平均与最大值都产生 1，求和分别产生 2 和 3。图只比较固定标量消息；求和本身也不能区分所有不同多重集，还需要合适的特征映射。

图同构网络 (graph isomorphism network, GIN) 使用求和聚合与前馈更新：

$$\mathbf{h}_i^{(l+1)} = \text{MLP}^{(l)} \left((1 + \epsilon^{(l)}) \mathbf{h}_i^{(l)} + \sum_{j \in N(i)} \mathbf{h}_j^{(l)} \right), \quad (11.22)$$

$\epsilon^{(l)}$ 可以固定或学习，用于区分中心节点与邻居的贡献。参数通过任务损失反向传播；整图读出还可拼接各层节点求和，保留不同传播范围的信息¹²。

比较两张图时，若存在保持连接关系及给定属性的节点重编号，使两图相互对应，就称它们**同构** (isomorphic)。图同构网络的名称并不表示它能判定任意两图是否同构。衡量其区分能力的一种参照是**一维 Weisfeiler-Leman 检验** (1-dimensional Weisfeiler-Leman test, 1-WL)：从与节点属性一致的初始标记出发，反复用“节点旧标记及邻居标记的多重集”产生新标记。所比较的图必须使用同一套无冲突标记规则，相同的输入组合得到相同标记，不同组合得到不同标记。每轮比较两图全部节点标记组成的多重集；只要有一轮不同，就可判为非同构，始终相同则不能证明同构。

对于只使用节点状态、对称邻域聚合且不引入额外区分信息的信息传递网络，1-WL 无法区分的图也不能靠这些更新与节点多重集读出区分：同标记节点具有同样的邻域标记多重集，共享计算逐轮产生同样的状态。

在可数特征域、邻域大小有界，以及聚合、更新和读出满足相应单射性条件时，求和特征映射可以达到 1-WL 的区分能力。**单射** (injective) 表示不同输入不会被映成同一个结果；有限宽度网络与训练算法并不自动满足该条件，也不能把这一理论直接推广为对所有连续特征无条件成立的保证。

¹² K. Xu, W. Hu, J. Leskovec, S. Jegelka, *How Powerful Are Graph Neural Networks?* In International Conference on Learning Representations, 2019

1-WL 本身也有边界。六节点环与两个互不连接的三角形都具有六个节点，每个节点度为 2。若初始节点特征全部相同，这两张图上的节点在每轮都会收到两个相同状态，任何上述消息传递加节点多重集读出都无法区分它们。增加传播轮数不能改变这一对称性；需要子结构信息、更高阶状态或其他符合任务要求的输入。能区分更多图是一种表达性质，也不等于训练样本上的泛化一定更好。

11.3.3 谱域与空域的联系、区别及选择

谱域与空域的区别主要在于怎样规定算子，而不是计算一定发生在哪一类存储空间。谱域用 $g_\theta(\lambda)$ 规定不同变化模式的响应，空域用邻居的选择、消息和聚合规定局部组合。若 g_θ 是多项式， $U g_\theta(\Lambda) U^T$ 等于同一多项式作用于 L ，便可完全通过节点域稀疏传播计算。ChebNet 由谱域设计、按邻域递推实现，GCN 也保留了谱域推导。因此，把谱域等同于特征分解、把空域等同于没有频率含义，会把这部分交集漏掉。

表 11.1 将显式谱实现与多项式实现分开。比较计算量时固定一张稀疏图与单通道线性传播，不计特征通道变换、消息网络及初次特征分解的代价；任意空域消息网络的成本还取决于其具体函数。

比较方面	显式谱基滤波	多项式谱滤波	局部空域聚合
算子定义	在图傅里叶模式上规定响应	用低阶多项式参数化响应	用邻居消息、权重及更新规定组合
实际计算	U^T 、对角滤波、 U	拉普拉斯的稀疏乘法递推	沿可见边计算，再按节点聚合
局部范围	自由响应通常涉及全图	K 次多项式至多读取 K 跳	一轮通常读取一跳；可另加长程边
传播成本	稠密基下 $O(n^2)$	$O(K(n+e))$	一跳简单聚合为 $O(n+e)$
跨图使用	按旧谱索引的自由参数缺少自然对应	共享多项式系数，在新图重建算子	共享消息规则，在新图读取邻域

表 11.1 谱域与空域图卷积的比较。显式谱基滤波表示直接使用完整图傅里叶基的实现；多项式谱滤波同时具有有限邻域解释。跨图使用一行只说明计算规则能否复用，不能据此保证新图上的预测效果。

在大图、多个大小不同的图或不断变化的图上，直接依赖完整 U 有几项实际困难。特征分解与稠密变换占用时间和存储，图结构改变后还需处理新的谱；按某张图谱索引学习的系数无法直接对应另一张图的模式。一般自由响应又不是严格局部的，一批目标节点可能依赖大量其他节点，难以只取少量邻居完成同一计算。这些条件解释了为何直接使用完整特征基的早期实现较少成为大规模局部模型的计算方式。

沿边的空域计算容易与邻居采样及小批次结合，也便于让消息读取边类型、方向和接收端内容。复杂度在稀疏图与固定宽度下可随边数增长，参数不必随节点数增加。这些是选择空域组织的具体理由，但局部可执行并不保证容易优化，也不自动解决有限传播距离、过平滑或过压缩。多项式谱滤波同样可以绕开特征分解并共享参数；不能把早期显式谱实现的全部困难归给它。

完整谱基、多项式滤波和空域聚合提供了不同的计算取舍，选择时应回到所需关系。若关心图信号哪些频率应保留或抑制，谱响应提供了直接的设计和分析对象；若需要不同边类型、内容相关交互或采样邻域，空域消息规则更便于表达这些计算。固定线性滤波、有限邻域与跨图复用可以同时成立；输入相关的非线性消息则未必是单个固定谱滤波器。比较两类网络时，应同时写清算子定义、实际实现、可见范围和数据条件。

谱滤波的后续研究继续改进参数化与计算方式。2022 年的 ChebNetII 通过切比雪夫插值组织可学习的谱响应，改进原有滤波器的参数化¹³。2026 年的 L2G-NET 研究图傅里叶变换的结构化分解，用子图谱表示及其组合处理局部与全局信息，针对完整谱变换的成本和局部性提出新的计算方式¹⁴。这些工作进一步探索了频率响应、局部传播和全局交互之间的联系，各自的收益需要结合任务与数据检验。

11.4 循环图神经网络

前面的网络可以为每层学习不同的变换。若希望同一套关系推理反复执行，就可以跨传播轮次共享参数。本节始终固定输入图；传播轮次表示算法内部更新次数，现实时间变化另在第 11.5.2 节处理。

11.4.1 网络结构

循环图神经网络 (recurrent graph neural network) 在同一图上反复更新节点隐状态。将全部状态按节点堆成列向量 $\mathbf{h}^{(t)} \in \mathbb{R}^{nm}$ ，令参数向量为 $\theta \in \mathbb{R}^p$ ，可写为

$$\mathbf{h}^{(t+1)} = F_{\theta}(\mathbf{h}^{(t)}; \mathcal{G}, \mathbf{X}), \quad \hat{\mathbf{y}} = g_{\theta}(\mathbf{h}^{(T)}). \quad (11.23)$$

F_{θ} 内部仍包含共享消息、聚合与节点更新；分号后的图与属性在各轮固定。图 11.7 显示同一规则的多次调用，每次调用的状态值不同。跨轮共享还要求相应状态维度兼容。

共享参数减少了随轮数增长的参数自由度，却没有减少必须执行的轮数。它也没有把多轮传播变成普通图上的最短路或逻辑推理算法；实际保留与传播什么信息仍由状态更新和监督决定。有限轮次模型与迭代至稳定的模型分别定义不同的输出。

11.4.2 典型模型

11.4.2.1 以不动点为目标的图网络

早期 GNN 把目标状态定义为**不动点** (fixed point)：再次使用更新函数后仍不改变的状态，即 $\mathbf{h}^* = F_{\theta}(\mathbf{h}^*; \mathcal{G}, \mathbf{X})$ 。它通过邻居状态迭代计算这一表

¹³ M. He, Z. Wei, J.-R. Wen, *Convolutional Neural Networks on Graphs with Chebyshev Approximation*, Revisited In Advances in Neural Information Processing Systems, 2022

¹⁴ S. Fernandez, E. Pavez, A. Ortega, *L2G-NET: Local to Global Spectral Graph Neural Networks via Cauchy Factorizations* In Proceedings of the 43rd International Conference on Machine Learning, 2026, pp. 30770–30798




图 11.7 固定图上的循环更新。左侧表示邻接关系，右侧展开三轮共享更新 F_θ ，每个状态向量包含整张图的节点状态。蓝色路径提供固定的图与输入特征，红色路径传递状态，黄色路径读出任务结果。轮次是内部计算步，不表示图已经发生三个时间点的变化。

示，再读取节点或图输出。为保证状态可确定，模型约束更新对状态具有收缩性；第 11.6.1 节将给出条件及误差界。

这类模型的参数既影响输出映射，也影响不动点的位置。有限精度计算通常在相邻两轮差小于容差时停止，并设置最大轮数。若未达到停止条件就触及上限，得到的是当前近似状态；不能把“程序停止了”当作“已经收敛到所定义的不动点”。收缩约束也限制了允许的状态动态，并非所有更新函数都满足它。

11.4.2.2 GGNN：固定轮次的门控传播

如果任务只需要执行有限步，可以直接学习这些步骤的结果。**门控图神经网络** (gated graph neural network, GGNN) 在聚合后用 GRU 式更新保留或写入状态。令 $r(i, j)$ 表示边的类型与方向，邻域输入为

$$\mathbf{a}_i^{(t)} = \sum_{j \in N(i)} \mathbf{W}_{r(i,j)} \mathbf{h}_j^{(t-1)} + \mathbf{b}, \quad \mathbf{h}_i^{(t)} = \text{GRU}(\mathbf{h}_i^{(t-1)}, \mathbf{a}_i^{(t)}). \quad (11.24)$$

这里 $\mathbf{a}_i^{(t)}$ 是聚合输入向量，与边属性 $\mathbf{a}_{i,j}$ 通过索引形式区分。原模型分别处理入边与出边并组合相应消息；式(11.24)写出一个统一的关系聚合形式，方向也可编码为不同类型¹⁵。

GRU 的门机制沿用第 10.4.2 节。若把更新门解释为写入比例，状态可写为 $\mathbf{h}_i^{(t)} = (\mathbf{1} - \mathbf{z}_i^{(t)}) \odot \mathbf{h}_i^{(t-1)} + \mathbf{z}_i^{(t)} \odot \tilde{\mathbf{h}}_i^{(t)}$ ；候选状态同时依赖聚合输入与经重置门处理的旧状态。门为节点提供选择性保留路径，远处证据则仍须沿边经过足够轮次。

GGNN 用预先设定的 T 轮展开计算并训练，不要求状态在 T 轮达到不

¹⁵ Y. Li, D. Tarlow, M. Brockschmidt, R. Zemel, *Gated Graph Sequence Neural Networks* In International Conference on Learning Representations, 2016

动点。它避免了为收敛强加同一类收缩约束，但也失去了由该约束直接得到的唯一稳定状态保证。训练时的轮次是模型设置；在预测时任意增加轮次，可能改变行为，不能默认等同于“推理更充分”。

11.4.3 参数学习

有限展开的梯度与随时间反向传播具有相同结构。设局部状态雅可比 $\mathbf{J}^{(t)} = \partial \mathbf{h}^{(t+1)} / \partial \mathbf{h}^{(t)}$ ， $\boldsymbol{\delta}^{(t)}$ 为第 t 轮状态的总梯度。若损失只读取末状态，则 $\boldsymbol{\delta}^{(t)} = (\mathbf{J}^{(t)})^\top \boldsymbol{\delta}^{(t+1)}$ ；中间轮存在直接监督时，另加对应梯度。共享更新参数的梯度为

$$\nabla_{\theta} L = \nabla_{\theta} L|_{\text{direct}} + \sum_{t=0}^{T-1} (\mathbf{B}^{(t)})^\top \boldsymbol{\delta}^{(t+1)}, \quad (11.25)$$

其中 $\mathbf{B}^{(t)} = \partial F_{\theta}(\mathbf{h}^{(t)}; \mathcal{G}, \mathbf{X}) / \partial \theta$ 固定当前输入状态求偏导。直接项包含读出参数等依赖；初态若依赖参数，还需计入初态梯度。截断展开会遗漏更早的间接贡献，降低存储与计算的同时改变所用梯度。

不动点模型还可利用**隐式微分**（implicit differentiation）：对定义状态的方程求导，而不保存全部前向迭代。假设更新在不动点附近可微，令 $\mathbf{J}_* = \partial F / \partial \mathbf{h}$ 、 $\mathbf{B}_* = \partial F / \partial \theta$ 在 $\mathbf{h}^*$ 处取值。若 $\mathbf{I} - \mathbf{J}_*$ 可逆，则

$$(\mathbf{I} - \mathbf{J}_*) \frac{\partial \mathbf{h}^*}{\partial \theta} = \mathbf{B}_*. \quad (11.26)$$

这个等式来自对 $\mathbf{h}^* = F_{\theta}(\mathbf{h}^*)$ 两侧求导，并把状态导数项移到左侧。

实际需要的是标量损失的梯度。记 $\mathbf{v} = \partial L / \partial \mathbf{h}^*$ 为列向量，解线性方程

$$(\mathbf{I} - \mathbf{J}_*^\top) \mathbf{u} = \mathbf{v}, \quad \nabla_{\theta} L = \nabla_{\theta} L|_{\text{direct}} + \mathbf{B}_*^\top \mathbf{u}. \quad (11.27)$$

无需显式求逆。若相应范数下 $\|\mathbf{J}_*\| < 1$ ，可用 $\mathbf{u}^{(k+1)} = \mathbf{v} + \mathbf{J}_*^\top \mathbf{u}^{(k)}$ 迭代；雅可比转置乘向量由自动微分计算。前向状态与后向线性求解都有容差，两者都会影响最终梯度的精度。

对只迭代到近似状态的模型，有限展开给出实际执行步骤的梯度，隐式方法近似理想不动点目标的梯度，二者在尚未充分收敛时未必相同。停止条件、最大轮数和状态收缩速度因而既影响前向代价，也影响参数学习。

11.5 图神经网络的扩展

普通图上的一套聚合规则把每条边都当成成对的信息通路。现实关系还可能具有不同语义，随时间变化，涉及多个参与者，或依赖空间位置。扩展模型需要保留这些输入差异，并把它们放到相应的消息、状态和对称性约束中。

11.5.1 多关系与异构图

“论文引用论文”与“作者撰写论文”不是同一种关系，把它们混在同一平均中会丢掉关系含义。**多关系图** (multi-relational graph) 允许边具有不同关系类型；**异构图** (heterogeneous graph) 还允许不同节点类型具有不同的属性和角色。两者可以同时存在，但边类型多并不必然意味着节点类型也不同。

设关系类型集合为 R , $N_r(i)$ 是通过类型 r 向 i 发送消息的邻居。**关系图卷积网络** (relational graph convolutional network, R-GCN) 为不同关系使用不同变换：

$$\mathbf{h}_i^{(l+1)} = \sigma \left(\mathbf{w}_0^{(l)} \mathbf{h}_i^{(l)} + \sum_{r \in R} \sum_{j \in N_r(i)} \frac{1}{c_{i,r}} \mathbf{w}_r^{(l)} \mathbf{h}_j^{(l)} \right). \quad (11.28)$$

$c_{i,r} > 0$ 是归一化系数，可在非空邻域取 $|N_r(i)|$ ；空邻域的求和直接为零。 $\mathbf{w}_0^{(l)}$ 负责自身状态， $\mathbf{w}_r^{(l)}$ 负责关系 r 。有向关系可增加单独的逆关系类型，使两个方向使用不同参数¹⁶。

关系数很大时，每种关系独立学习一个稠密矩阵会增加参数与数据需求。可以用基分解 $\mathbf{w}_r = \sum_{b=1}^B \mathbf{a}_{r,b} \mathbf{V}_b$ ，让各关系共享 B 个基础矩阵，只学习不同系数。固定输入输出宽度 m 时，参数量由 $|R|m^2$ 改为 $Bm^2 + |R|B$ ，代价是关系变换被限制在同一矩阵子空间。

不同节点类型的原始特征维度可能不同，可以先用类型相关的输入映射投射到公共空间，再按关系传递。聚合还可先在每种关系内部组合，再学习关系间权重。置换等变性在重编号后仍成立，但类型也须跟着节点与边重排；它不要求把作者属性与论文属性互换后保持预测不变。

11.5.2 动态图

社交互动、交易和设备关系会随时间改变。**动态图** (dynamic graph) 把节点、边或属性的变化作为输入的一部分，模型不仅要处理当前关系，还要确定哪些历史在预测时可见。固定图上的十轮传播仍是同一个输入的十次内部计算，与现实中经过十个观测时刻不同。

一种表示是**图快照** (graph snapshot)：在时刻 t 取得 $\mathcal{G}_t$ 与 $\mathbf{X}_t$ ，先在每张快照中编码，再沿时间更新。对持续存在的节点可写为

$$\mathbf{z}_{i,t} = \text{GNN}(\mathcal{G}_t, \mathbf{X}_t)_i, \quad \mathbf{s}_{i,t} = \text{GRU}(\mathbf{s}_{i,t-1}, \mathbf{z}_{i,t}). \quad (11.29)$$

这里 $\mathbf{z}_{i,t}$ 包含当前图中的邻域信息， $\mathbf{s}_{i,t}$ 维护跨时间历史。节点身份用于对齐相邻快照中的同一个对象；新节点的初态、节点消失后的状态保留与重现规则也要约定。快照间隔决定哪些短时事件被合并或遗漏。

¹⁶ M. Schlichtkrull, T. N. Kipf, P. Bloem, R. van den Berg, I. Titov, M. Welling, *Modeling Relational Data with Graph Convolutional Networks* In The Semantic Web, 2018, pp. 593–607

另一种表示是带时间戳的**事件序列** (event sequence)，例如第 q 个事件 $(i_q, j_q, \tau_q, \mathbf{a}_q)$ 表示两个节点在时刻 τ_q 发生互动。每个节点维护自己的记忆，在事件发生后更新相关状态。消息可以读取两端的事件前记忆、事件属性，以及距离该节点上次更新的时间间隔；不参与事件的节点记忆可以暂时保留。TGN 以消息函数、消息聚合、记忆更新和时序表示等模块组织这一类计算¹⁷。

预测互动是否发生时，应先用事件发生前的历史评分，再用实际发生的事件更新记忆。若把待预测互动写入邻接关系或记忆后才评分，答案已经成为输入。批量事件处理也要明确是否能读取同批中较早的事件；同一时刻的事件若没有已知顺序，不能随意用存储次序制造先后依赖。

训练时可沿快照或事件展开反向传播，并在长流中按需要截断。评估未来事件时按时间划分，状态只由约定的可见历史推进；评估新节点时还要额外检查训练阶段是否已经接触其信息。内部传播深度、历史记忆长度和观测时间间隔共同影响计算，但衡量的是三种不同范围。

11.5.3 高阶关系

一次多人合作对应一个参与者集合，单条普通边只能描述两个对象。**超图** (hypergraph) 用**超边** (hyperedge) 表示同时连接多个节点的关系。记 $\mathcal{H} = (V, \mathcal{E})$ ，其中 $\mathcal{E}$ 是节点子集的集合；一条超边 $S_a \subseteq V$ 保留这次关系的完整参与组。将它拆成所有成对边，可能无法区分“一次三人合作”与“三次两人合作”。

图 11.8 展示一种计算表示：先让节点向超边聚合，再让超边把结果传回参与节点。将每条超边作为额外对象，会得到节点与关系对象构成的二部图；超边属性及非线性变换可以放在中间状态上。

令**关联矩阵** (incidence matrix) $\mathbf{B} \in \{0, 1\}^{n \times h}$ 记录节点是否属于超边， $h = |\mathcal{E}|$ ， $\mathbf{B}_{i,a} = 1$ 表示 $i \in S_a$ 。设超边权重为 $w_a > 0$ ， $\mathbf{W}_e = \text{diag}(w_1, \dots, w_h)$ ，节点度 $d_i = \sum_a \mathbf{B}_{i,a} w_a$ ，超边大小 $s_a = \sum_i \mathbf{B}_{i,a}$ 。对非空超边及非孤立节点，一个归一化的传播为

$$\mathbf{H}' = \sigma(\mathbf{D}_v^{-1/2} \mathbf{B} \mathbf{W}_e \mathbf{D}_e^{-1} \mathbf{B}^\top \mathbf{D}_v^{-1/2} \mathbf{H} \mathbf{\Theta}), \quad (11.30)$$

其中 $\mathbf{D}_v = \text{diag}(d_i)$ 、 $\mathbf{D}_e = \text{diag}(s_a)$ ， $\mathbf{\Theta}$ 是特征变换矩阵。关联矩阵转置把节点信息汇到超边，关联矩阵再将结果送回节点；HGNN 采用了这一类归一化超图卷积¹⁸。

超图输入与更强表达能力仍须区分。式(11.30)的线性传播部分可以合成一个节点间矩阵，若两张超图产生相同矩阵，这一层也不能保留它们不同的组关系。若任务依赖具体组的区别，需要保留超边状态、属性或组内非线性，不能仅凭输入被称为超图就认定信息已经完整利用。

¹⁷ E. Rossi, B. Chamberlain, F. Frasca, D. Eynard, F. Monti, M. Bronstein, *Temporal Graph Networks for Deep Learning on Dynamic Graphs* In arXiv preprint arXiv:2006.10637, 2020

¹⁸ Y. Feng, H. You, Z. Zhang, R. Ji, Y. Gao, *Hypergraph Neural Networks* In Proceedings of the AAAI Conference on Artificial Intelligence, 2019, pp. 3558–3565




图 11.8 超边及其关联表示。左侧一条超边 S_a 连接节点 1、2、3，另一条超边 S_b 连接节点 3、4。右侧将超边画成方框，以连线表示参与关系；下方 4×2 关联矩阵 H 用同一组 0 / 1 关系把“集合、二部图、矩阵”对应起来。方框是关系状态，不是新增的原始参与者。

另一类**高阶图网络** (higher-order graph neural network) 把节点组作为状态对象，例如为节点对维护 $\mathbf{h}_{i,j}$ ，使网络能够组合单节点状态难以保留的关系。它不一定需要外部提供超边，而是改变计算状态的索引与交互方式。Morris 等将这种思路与高阶 WL 方法联系起来¹⁹。若显式维护所有 k 元节点组，状态数可达 $O(n^k)$ ；选取部分子结构或局部组可以降低代价，但相应的区分能力也要重新说明。

11.5.4 几何关系与对称性约束

原子或物体除了连接关系，还可能具有坐标 $\mathbf{r}_i \in \mathbb{R}^3$ 。若把绝对坐标直接送入普通前馈消息函数，平移或转动物体就可能改变标量属性预测。几何任务需要另外指定对称性：能量等标量通常要求对整体平移和旋转不变；预测的位移或力则应随坐标系一起旋转。

令 $\mathbf{r}'_i = \mathbf{Q}\mathbf{r}_i + \mathbf{t}$ ，其中 $\mathbf{t} \in \mathbb{R}^3$ 是平移，正交矩阵 $\mathbf{Q}$ 满足 $\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}_3$ 。相对位移随 $\mathbf{Q}$ 旋转，距离 $\|\mathbf{r}_i - \mathbf{r}_j\|_2$ 保持不变。用距离和其他不变属性产生标量消息，再用标量系数乘相对位移，就能构造等变的坐标更新。一个 EGNN

¹⁹ C. Morris, M. Ritzert, M. Fey, W. L. Hamilton, J. E. Lenssen, G. Rattan, M. Grohe, *Weisfeiler and Leman Go Neural: Higher-Order Graph Neural Networks* In Proceedings of the AAAI Conference on Artificial Intelligence, 2019, pp. 4602–4609

式的层可写为

$$\begin{aligned}
 \mathbf{m}_{i \leftarrow j} &= \phi_e(\mathbf{h}_i, \mathbf{h}_j, \|\mathbf{r}_i - \mathbf{r}_j\|_2^2, \mathbf{a}_{i,j}), \\
 \mathbf{r}'_i &= \mathbf{r}_i + c_i \sum_{j \in N(i)} (\mathbf{r}_i - \mathbf{r}_j) \phi_r(\mathbf{m}_{i \leftarrow j}), \\
 \mathbf{h}'_i &= \phi_h \left(\mathbf{h}_i, \sum_{j \in N(i)} \mathbf{m}_{i \leftarrow j} \right).
 \end{aligned} \tag{11.31}$$

ϕ_r 输出标量, c_i 是与坐标变换无关的归一化系数, $\mathbf{h}_i$ 此处由旋转不变的标量通道组成。EGNN 使用距离构造消息, 并用这种相对位移加权实现欧氏变换等变性²⁰。

证明只需跟踪各对象的变化。距离不变, 所以消息及 ϕ_r 不变; 相对位移变为 $\mathbf{Q}(\mathbf{r}_i - \mathbf{r}_j)$, 整段坐标增量随 $\mathbf{Q}$ 变换, 加回 $\mathbf{Q}\mathbf{r}_i + \mathbf{t}$ 后得到原更新结果的同一变换。邻接构造也须遵守该对称性, 例如按距离阈值建边; 若按固定坐标轴上的绝对位置选边, 消息函数对称仍不足以保证整个模型对称。

正交矩阵还包括镜像反射。距离不变的模型因此可能无法区分互为镜像的手性构型; 若目标会因镜像而改变, 就需要只约束适用的对称群, 并引入能保留相应方向关系的信息。对称性必须来自任务, 不能为了方便把本该保留的差别抹掉。

若标量能量预测 $\hat{E}$ 可微且具有相应不变性, 定义 $\hat{\mathbf{f}}_i = -\nabla_{\mathbf{r}_i} \hat{E}$ 可以得到随旋转等变的力预测。这个构造保证输出间的数学一致性, 却不保证学到的能量或力具有足够精度; 仍需合适监督、结构覆盖及数值计算。

²⁰ V. G. Satorras, E. Hoogeboom, M. Welling, *E(n) Equivariant Graph Neural Networks* In Proceedings of the 38th International Conference on Machine Learning, 2021, pp. 9323–9332

11.6 理论分析

图结构改变了信息的传播路径, 也改变了训练数据的依赖方式。讨论理论性质时, 需要明确是在固定参数下计算状态、比较输入表示, 还是从有限样本学习参数。一个层面的良好性质不能直接替代另一个层面的保证。

11.6.1 收敛与信息传播

11.6.1.1 状态收敛及其条件

不动点模型需要知道反复更新是否会停在确定的状态。一个充分条件是**收缩映射** (contraction mapping): 对同一输入, 两份状态经过更新后距离按小于 1 的固定比例缩小。这里的距离针对整张图的状态, 不能只检查单个节点的激活函数。

定理 11.4 收缩更新的唯一不动点 固定 $\mathcal{G}$ 、 $\mathbf{X}$ 和参数 θ 。设 F_θ 把非空闭状态域 $\mathcal{S}_{\text{state}} \subseteq \mathbb{R}^{nm}$ 映到自身，且某个范数下存在 $c \in [0, 1)$ ，使任意 $\mathbf{u}, \mathbf{v} \in \mathcal{S}_{\text{state}}$ 满足

$$\|F_\theta(\mathbf{u}) - F_\theta(\mathbf{v})\| \leq c\|\mathbf{u} - \mathbf{v}\|.$$

则 $\mathcal{S}_{\text{state}}$ 中存在唯一不动点 $\mathbf{h}^*$ ，任意该域内初态的迭代都收敛到它，并满足

$$\|\mathbf{h}^{(t)} - \mathbf{h}^*\| \leq c^t \|\mathbf{h}^{(0)} - \mathbf{h}^*\|. \quad (11.32)$$

证明. 相邻迭代差至多按 c 的幂衰减，其尾和被收敛几何级数控制，故状态构成 Cauchy 序列。闭域在有限维范数下完备，极限属于 $\mathcal{S}_{\text{state}}$ ，由 F_θ 的连续性成为不动点。若存在两个不动点，其距离至多为自身的 c 倍，只能为零。把收缩不等式逐轮用于状态与不动点，得到误差界。 ■

这一证明还给出可检查的误差证书：对 $t \geq 1$ ， $\|\mathbf{h}^{(t)} - \mathbf{h}^*\| \leq c(1 - c)^{-1} \|\mathbf{h}^{(t)} - \mathbf{h}^{(t-1)}\|$ 。 c 接近 1 时，相邻差小不代表离不动点已经同样近；迭代速度和停止容差要放在一起解释。

例如采用矩阵状态更新 $\mathbf{H}' = \sigma(\mathbf{SHW} + \mathbf{B}_x)$ ，其中 $\mathbf{B}_x \in \mathbb{R}^{n \times m}$ 为固定输入项。若 σ 是 L_σ -Lipschitz 的，则 Frobenius 范数下

$$\|\mathbf{H}'_1 - \mathbf{H}'_2\|_F \leq L_\sigma \|\mathbf{S}\|_2 \|\mathbf{W}\|_2 \|\mathbf{H}_1 - \mathbf{H}_2\|_F. \quad (11.33)$$

乘积小于 1 且状态域不变时，可应用定理。未经归一化的求和传播可能因最大节点度增大而放大该上界；对称归一化的无向 GCN 传播满足 $\|\mathbf{S}\|_2 = 1$ 。门控中的门值落在 $[0, 1]$ 仍不足以单独保证收缩，因为门自身也随状态变化。

收缩保证的是固定参数下的状态计算。参数更新会改变 F_θ ，整个训练目标通常仍然非凸；收敛到状态不动点不等于参数优化收敛，更不等于训练或测试损失小。收缩也是充分条件而非必要条件，有限轮次模型本来就不要求以不动点定义输出。

11.6.1.2 过平滑：节点区分信息消失

传播扩大感受野，却可能把不同节点的表示反复混在一起。**过平滑** (over-smoothing) 指传播加深后，与节点差异有关的信息不断减少，以致任务需要的区分难以保留。它可以发生在没有循环共享参数的深层网络中，也不要求所有坐标在字面上完全相等。

先看一个能够精确求解的简化模型：令激活与通道变换都为恒等，只反复计算 $\mathbf{H}^{(l+1)} = \mathbf{SH}^{(l)}$ 。假定非负无向图连通，并在每个节点加入正自环；




图 11.9 过平滑的二维投影示意。五种颜色始终代表同五个节点，位置只是人为构造的表示投影，并非 t-SNE 实验；随着传播层数增加，点间最大距离缩小，节点身份仍在但可供下游区分的表示差异逐渐消失。过平滑描述的是任务相关差异受损，不要求所有坐标严格相等。

对应 $\mathbf{S}$ 具有唯一特征值 1，其余特征值的绝对值小于 1。定义单位向量

$$q_i = \frac{\sqrt{\tilde{d}_i}}{\sqrt{\sum_j \tilde{d}_j}},$$

则特征分解给出

$$\mathbf{S}^L \mathbf{X} \longrightarrow \mathbf{q} \mathbf{q}^\top \mathbf{X}, \quad \|\mathbf{S}^L \mathbf{X} - \mathbf{q} \mathbf{q}^\top \mathbf{X}\|_F \leq \rho^L \|\mathbf{X}\|_F, \quad (11.34)$$

其中 ρ 是其他特征值绝对值的最大值。证明依据是 $\mathbf{q}$ 方向保持不变，其正交方向每次乘以绝对值至多为 ρ 的特征值。

极限中，每个节点只剩同一个特征向量的度相关倍数；除以 $\sqrt{\tilde{d}_i}$ 后便相同。若图不连通，每个连通分量保留一个相应方向；若没有破除周期的条件，例如无自环的二部图，状态还可能振荡。因而连通性、归一化与自环都是结论的条件，不能省略。

真实 GCN 还含非线性、学习权重与跨层连接，不能直接把式(11.34)视为它们的全部行为。Oono 与 Suzuki 在特定激活及参数范数条件下进一步分析了表示靠近低维子空间的速度，说明传播谱与权重尺度需要联合考察²¹。低频聚合在有限深度可能有用，任务需要保留的差异被过度削弱时才构成问题。

残差连接可以为旧表示保留额外路径，跨层拼接或读出可以直接读取较浅表示，初始特征注入则持续补充原始节点差异。这些设计改变了反复纯混合的形式。仅给传播加一个恒等分支后再归一化，仍可能逐步混合，因此不能只凭出现“残差”就认定过平滑已经消失。

²¹ K. Oono, T. Suzuki, *Graph Neural Networks Exponentially Lose Expressive Power for Node Classification* In International Conference on Learning Representations, 2020

11.6.1.3 过压缩：远处信息通过狭窄通路

另一种困难是节点需要利用许多远处对象，但这些信息只能经少量中间状态到达。**过压缩** (oversquashing) 指大量关系信息沿传播路径汇入有限维状态或狭窄连接时，任务所需的远处影响难以有效传递。它关注路径与容量，而不是节点表示是否趋同；Alon 与 Yahav 从这一信息瓶颈出发分析了长程图任务²²。

一个二叉树例子能展示具体机制。设每个内部节点只把两个子节点的标量取平均，深度为 k 的 2^k 个叶子为 x_j ，则根状态为 $h_{\text{root}} = 2^{-k} \sum_j x_j$ ，对单个叶子的导数为 2^{-k} 。距离增加时，每个叶子的单独影响迅速衰减；但根与各叶状态并没有被要求相同。图 11.10 将汇聚树与图中的狭窄连接对应起来。

²² U. Alon, E. Yahav, *On the Bottleneck of Graph Neural Networks and Its Practical Implications In International Conference on Learning Representations*, 2021




图 11.10 两种信息汇聚瓶颈。左侧八个叶子经三层平均进入一个根状态，每个叶子的影响系数为 $1/8$ ；右侧两组节点的跨组信息必须经过一条桥边。红色表示承担汇聚或跨组传递的状态，蓝色表示外围输入。图不要求所有状态相同，强调的是大量信息必须经过较少的表示通路。

若目标恰是叶子的平均，这种压缩就是所需计算；若目标要根据查询分别检索某个叶子，单一平均已经丢掉必要差别。因此，过压缩要相对于任务解释。有限维实数在无限精度下还可能编码大量离散信息，不能只凭维度给出不带连续性、噪声或有限精度条件的绝对存储不可能性结论。

增加状态宽度可以提供更多通道，增加传播轮次可以到达更远处，却也可能增加汇入同一状态的信息量。修改图结构、加入长程连接或全局读取，可以缩短路径并扩大跨区域通路；这些做法也改变了关系假设和计算量。残差主要保留已有信息路径，未必能解除一条桥边上的瓶颈。状态收敛、过平滑与过压缩因而需要分别诊断，再选择对应设计。

11.6.2 泛化能力

11.6.2.1 样本单位与图上的依赖

对分子属性预测，一张分子图及其标签可以作为一个样本，图内节点允许相互依赖。若 N 张图独立同分布，前面学习理论中的样本量就是 N ，并不是所有原子数的总和。若多张图来自同一系统的连续快照，或由一张大图截取重叠片段，它们未必独立。

单张引用图上的节点分类具有另一种组织方式：输入结构与特征可以共享，节点标签及其邻域又相互关联。随机选若干标签做训练，并不把全部节点变成独立同分布图样本。固定图上的未标记节点风险可以采用直推分析；从一个图生成模型抽样时，需要把相应结构依赖写进假设。不能把独立样本界中的分母直接改成节点数，就声称相关性已经得到处理。

同样，邻域互不重叠也不自动保证样本独立，可能仍有共同的生成因素。样本划分应对应未来使用：已知图上的剩余标签、全新图、全新节点和未来事件分别有不同的信息边界。比较不同模型时，必须固定这一边界。

11.6.2.2 输入尺度、度与参数范数

在独立整图设定下，结构怎样进入泛化分析，可以先从网络敏感度考察。考虑无偏置层 $\mathbf{H}^{(l+1)} = \sigma(\mathbf{S}\mathbf{H}^{(l)}\mathbf{W}^{(l)})$ ，激活为 1-Lipschitz 且零点取零。对同一图上的两份特征，固定参数后有

$$\|\mathbf{H}^{(L)} - \tilde{\mathbf{H}}^{(L)}\|_F \leq \|\mathbf{S}\|_2^L \prod_{l=0}^{L-1} \|\mathbf{W}^{(l)}\|_2 \|\mathbf{X} - \tilde{\mathbf{X}}\|_F. \quad (11.35)$$

每层先用激活的 Lipschitz 性，再用矩阵乘法的范数界，逐层相乘即得。它控制固定结构下的输入扰动；若边同时改变，还必须增加传播算子变化的项。

未经归一化的邻接求和在无向图上满足 $\|\mathbf{A}\|_2 \leq d_{\max}$ ，其中 $d_{\max}$ 是最大加权重。这个上界可能随深度以 $d_{\max}^L$ 进入敏感度；标准对称归一化将传播的谱范数控制为 1。归一化因而可以改变尺度控制，但也改变了度与计数信息，不能只根据范数界判断哪种模型在所有任务上更好。

读出又带来规模差别。平均读出满足 $\|n^{-1}\mathbf{1}^\top \mathbf{H}\|_2 \leq \|\mathbf{H}\|_F / \sqrt{n}$ ，求和读出的对应系数为 $\sqrt{n}$ 。若每个节点输入范数不超过 B_x ，则 $\|\mathbf{X}\|_F \leq B_x \sqrt{n}$ ；平均与求和对应的输出上界分别消去或保留节点规模。宽度、偏置、注意力评分和关系参数还会改变其余常数，需按实际模型计入。

对权重扰动也可逐层计算。只改变第 k 层权重时，当前误差至多为 $\|\mathbf{S}\|_2 \|\mathbf{H}^{(k)}\|_F \|\Delta \mathbf{W}^{(k)}\|_2$ ，后续层再乘各自的尺度界。逐个替换所有层并用三角不等式，可以建立输出对全部参数的统一 Lipschitz 上界。深度影响重

复传播和误差累积，参数共享限制自由度，却不取消同一参数反复使用的敏感度。

11.6.2.3 从参数约束到风险界

敏感度还不是泛化结论；需要结合样本抽样和受约束的候选函数族。下面给出一个便于检查条件的整图预测界，承接统计学习部分的一致收敛思路，不假定独立节点。

定理 11.5 有界参数图预测的覆盖界 设 $Z_1, \dots, Z_N$ 是独立同分布的整图及标签样本。预先固定的参数域 $\Theta \subseteq \mathbb{R}^p$ 包含在半径 $B_\theta > 0$ 的欧氏球内，损失 $\ell_\theta(Z) \in [0, 1]$ 关于样本可测，且对全部允许的样本与参数有

$$|\ell_\theta(Z) - \ell_{\tilde{\theta}}(Z)| \leq a \|\theta - \tilde{\theta}\|_2$$

其中 $a > 0$ 为预先给定的统一常数。记期望风险 $R(\theta) = \mathbb{E} \ell_\theta(Z)$ 与经验风险 $\hat{R}_N(\theta) = N^{-1} \sum_q \ell_\theta(Z_q)$ 。对任意预先固定的 $\varepsilon > 0$ 与 $\delta \in (0, 1)$ ，以至少 $1 - \delta$ 的概率，

$$\sup_{\theta \in \Theta} |R(\theta) - \hat{R}_N(\theta)| \leq 2\varepsilon + \sqrt{\frac{p \log(1 + 2B_\theta a/\varepsilon) + \log(2/\delta)}{2N}}. \quad (11.36)$$

证明. 欧氏球内的参数集合有半径 ε/a 的覆盖，中心取自 Θ ，覆盖数至多为 $(1 + 2B_\theta a/\varepsilon)^p$ 。对每个中心的有界损失使用 Hoeffding 不等式，再用并合界，得到平方根项。任意参数到最近中心的损失差不超过 ε ，期望风险与经验风险各增加至多 ε ，合计得到 2ε 。 ■

这个界把独立图数、参数自由度、参数范围和统一敏感度放在同一表达式中。前面的范数推导可以在限定图规模、特征尺度与网络结构后帮助构造 a ；图拓扑及度会通过传播算子进入它。假设对全部允许样本成立很关键：仅在训练图上测到较小梯度，不足以建立同样的统一覆盖保证。

原始交叉熵无上界，不能直接代入 $[0, 1]$ 条件；可使用有界替代损失，或在额外概率下界及尺度处理后重新分析。这个参数覆盖界也可能很松，它展示的是一条充分条件路线，而不是精确预测测试误差的公式。Rademacher 复杂度可以更细地利用样本和函数约束，算法稳定性则研究替换一个完整图样本后学习结果的变化；采用哪一种工具，都必须与样本单位和损失条件对应。

结构设计还影响拟合偏差。更强的对称性减少无关自由度，却可能排除任务需要的方向差异；更强的聚合区分能力扩大可表达的函数，也需要数

据与学习过程支持。残差提供额外路径时，其 Lipschitz 上界常出现 $1+$ 分支尺度，不能因为梯度路径改善就宣称复杂度界一定降低。

测试图比训练图更大、节点度分布不同，或关系类型及标签机制变化时，已经改变了输入分布。共享更新可以在新规模上执行，仍不保证超出训练范围的误差保持不变。应分别报告同分布整图泛化、固定图直推表现及跨规模或跨分布结果，把结构优势与数据条件放在一起解释。

11.7 常见应用

以下三个任务使用不同预测对象，但都需要把可见关系、编码器、输出和监督对应起来。具体领域的特征工程、评估协议和应用方法留给应用卷，这里展示一个完整模型如何接入任务。

11.7.1 节点分类

以论文引用网络为例，每篇论文是节点，内容向量是 $\mathbf{x}_i$ ，引用是有向边。若任务允许同时读取引用与被引用的信息，可以分别使用两个方向，或明确把图无向化；后一种选择会丢掉方向差别。内容编码器只使用约定的可见文本，类别标签另放在监督集合中。

一个基本模型是两层 GCN: $\mathbf{H}^{(1)} = \text{ReLU}(\mathbf{S}\mathbf{X}\mathbf{W}^{(0)})$ ，节点概率矩阵为 $\mathbf{P} = \text{softmax}_{\text{row}}(\mathbf{S}\mathbf{H}^{(1)}\mathbf{W}^{(1)})$ ，Softmax 逐行作用。按式(11.4)仅在训练节点上计算交叉熵，反向更新两层权重。两轮传播使每个预测可以读取两跳以内的内容与连接信息。

直推设定下，验证和测试节点的无标签特征与连接可以按协议参与编码；类别标签用于各自的评估，不能进入训练计算。若预测未来发表的论文，则训练时不得使用未来引用边和文本，内容编码、建图及归一化也须按当时可见的信息重建。相同两层公式可以用于两种设定，但它们回答的是不同泛化问题。

还应比较只使用内容的前馈基线，以检查关系是否提供了额外信息。邻居类别常相近时聚合可能有用；关系跨越类别边界时，需要分开自身与邻居、处理方向或关系类型，不能预设相邻论文属于同类。

11.7.2 连接预测

关系网络中，编码器先在可见图上产生 $\mathbf{z}_i = \mathbf{h}_i^{(L)}$ ，解码器再为候选节点对评分。无向连接可用 $s_{i,j} = \mathbf{z}_i^T \mathbf{z}_j$ ；有向关系可用 $s_{i,j} = \mathbf{z}_i^T \mathbf{R} \mathbf{z}_j$ ，一般矩阵 $\mathbf{R}$ 允许交换端点后得分变化。多关系任务可把 $\mathbf{R}$ 改为类型相关参数。

训练批次包含已知正连接及从候选范围抽出的负样本，按式(11.5)联合更新编码器与评分参数。未观察到的边并不一定是真实负例，它可能只是

尚未记录；采样范围、正负比例和缺失机制决定目标的含义。以人为采样比例训练的 Sigmoid 得分，也不能未经校准就当作现实连接概率。

评估保留连接时，需要从编码图中移除这些边及其反向副本，避免编码器直接读取答案。训练正边是否在给该边评分时仍参与编码，也应说明；可以另外划分用于消息传递与用于监督的正边，或在批次中临时屏蔽目标边，使训练输入与目标评估口径对应。对未来连接，则先用历史图评分，事件发生后再更新动态图状态。

预测时对所需候选评分和排序。全部节点对数量为 $O(n^2)$ ，即使编码器在稀疏图上计算，枚举全部候选仍可能昂贵。候选生成与负样本改变评价难度，比较模型时需要固定它们；容易的随机负例上的高分不代表已解决实际候选中的关系判断。

11.7.3 整图属性预测

以分子属性预测为例，节点表示原子，边表示化学键。原子种类、形式电荷等作为节点属性，键类型等作为边属性，消息函数据此产生固定宽度向量。传播若干轮后，通过式(11.3)形成分子表示，再用前馈输出头预测标量，按式(11.6)学习。输入编码、消息函数、更新与输出头共同接受梯度。

读出选择要与属性性质对应。随体系大小累积的量可以采用节点贡献求和的结构，强调整体分子组成；与规模不直接成比例的量可以使用平均或更一般的可学习读出。真实属性是否可由局部贡献充分表达仍取决于任务，不能把求和形式直接当作物理正确性的保证。

只有二维连接关系时，网络不知道同一分子不同空间构型的坐标差别。若目标依赖三维构型，需要把预测时可得的坐标与几何关系纳入，并按第 11.5.4 节处理对称性。近邻空间图与化学键图还可以承担不同关系通路，不能将二者的边含义混同。

训练和测试按完整分子划分；同一分子的多种构型或高度相近的结构是否跨划分，需要与目标使用场景对应。仅随机分图可能主要检查近似结构间的插值，按结构族划分则考察更远的迁移。验证图用于选择传播深度、宽度与读出，测试图用于评价相应设定下的预测误差。

11.8 本章小结

图神经网络沿关系传递信息，用共享消息与对称聚合处理数量不定、次序无关的邻域。节点表示随重编号等变，整图读出对重编号不变。多轮传播扩大可见范围，聚合、状态宽度与拓扑则共同决定能否保留任务需要的信息。

谱域滤波通过多项式转为局部传播，GCN 体现了它与空域聚合的联系。

采样、内容加权和多重集区分解决不同问题；循环共享则须区分有限展开与不动点求解。关系类型、时间、高阶关系和几何对称性进一步规定了哪些信息必须保留。

状态梯度沿前向读取反向回传，并汇合为共享参数的导数；训练趋于驻点需要目标、梯度估计与步长满足相应条件。固定参数的状态收敛保证求值，过平滑描述节点差异消失，过压缩描述远处信息受到狭窄通路限制。建模时须确定可见关系与适用对称性，选择任务读出，再用匹配的监督和划分检验。结构能够在新图上执行是起点，可靠性仍须结合样本依赖、图分布与参数尺度考察。

Transformer

在第10.5节中，解码器可以根据当前需求读取不同输入位置，不必把整段输入的细节都挤进一个末状态。但编码状态仍沿时间逐步形成，解码状态也依赖前一步。如果各位置已经全部可见，能否让它们直接交换信息，再通过层间计算逐步形成表示？如果输出尚未产生，这种计算又怎样遵守“只能读取已知内容”的约束？

Transformer 将这两个问题分开处理：注意力决定一个位置从哪些位置读取信息，层间堆叠决定这些信息怎样变成新的表示。输入顺序、预测目标和可见范围需要明确写进网络，而计算与存储代价也随读取方式改变。本章围绕这组关系建立网络结构和梯度计算，再比较位置、注意力、前馈与连接方式的扩展，分析学习结论的条件，并将它们接到分类、转换、生成和图像任务中。

12.1 Transformer 概述

Transformer 把序列中的信息传递从时间递推转为位置间读取与层间更新。理解这一变化，需要同时看注意力的读取机制、网络架构的发展，以及并行计算与存储之间的取舍。

12.1.1 从循环计算到位置间读取

循环注意力中的查询来自解码状态，候选表示来自编码状态；它使每一步可以重新选择上下文，却保留了状态递推。**自注意力**（self-attention）把查询和候选表示都取自同一组输入：每个位置根据自身表示，选择同一序列中其他位置的信息。例如，在“这部电影并不精彩”中，表示“精彩”的位置可以直接读取“并不”，形成带有上下文的表示。读取是否正确仍由训练决定，连接的存在只提供了计算路径。

Transformer 是一类以注意力进行位置间交互、以逐位置前馈网络进行特征变换的网络。一次自注意力可以同时更新所有已知位置；下一层再读取上一层得到的表示。这里的层间依赖与普通循环网络的时间递推不同：

同层各位置不需要等前一个位置先更新完成。稠密自注意力在允许读取的任意位置对之间建立直接路径，但每个位置收到的是加权混合，仍需足够的特征容量和后续变换来保留任务相关区别。

12.1.2 注意力机制的发展

注意力机制始终围绕一个问题展开：当前计算应该优先使用哪些信息？早期视觉模型通过选择观察位置分配处理资源，后来的序列模型通过可学习权重读取已有表示。沿着这两条相互交汇的路线，可以看清注意力如何从局部选择机制发展为 Transformer 中的基本运算。

早期视觉注意力：选择在哪里观察 1985 年，Koch 与 Ullman 提出选择性视觉注意力的计算模型：不同视觉特征共同形成**显著图** (saliency map)，即标出各位置有多突出的空间分布；模型选出突出位置，再抑制已选位置，使注意转向其他区域。这类模型着重解释视觉资源如何在空间中分配，还不是后文用查询、键和值进行加权聚合的运算¹。

神经网络随后被用于学习观察策略。Schmidhuber 与 Huber 在 1991 年的工作中，用神经控制器移动“人工中央凹”，即中心精细、外围粗略的局部观察区域，以逐步找到和跟踪目标。控制器借助学到的环境模型改进移动轨迹，而不是由教师逐步指定应看哪里²。2014 年，Mnih 等用循环网络整合多次局部观察，并学习下一次观察的位置。这种先采样位置、再读取局部输入的方式属于**硬注意力** (hard attention)；由于普通梯度不能直接穿过这种采样选择，论文使用强化学习方法训练位置策略³。

机器翻译：从固定上下文到软对齐 序列转换遇到的是另一种信息瓶颈：编码器已经读完整句，但若只把一个固定向量交给解码器，每个目标词都要从同一压缩结果中恢复细节。Bahdanau、Cho 与 Bengio 于 2014 年发布、2015 年发表于 ICLR 的工作保留所有源位置的编码状态，在生成每个目标词之前，用此前的解码状态重新为这些源状态评分。得分经 Softmax 变成权重，再加权求和，形成随生成步变化的上下文。模型不必只选一个源位置，整个聚合过程可微，能和翻译目标一起训练；这就是**软注意力** (soft attention) 形成的软对齐⁴。

例如翻译“猫追狗”时，预测 cat 与预测 dog 所需的源信息不同，读取权重可以随之改变；“对齐”表示目标步与源位置之间学到的软对应，不要求人工提供逐词对齐标签。这项工作中的加性注意力用一个小前馈网络评估两种状态是否匹配，具体公式已见式(10.26)。它解决了如何动态读取源表示的问题，编码器与解码器本身仍然逐步递推。

2015 年，Luong 等系统比较了直接点积、带参数的双线性形式等评分方式，并区分读取全部源位置的全局注意力与只读取一个窗口的局部注意

¹ C. Koch, S. Ullman, *Shifts in Selective Visual Attention: Towards the Underlying Neural Circuitry In Human Neurobiology*, 1985, vol. 4, no. 4, pp. 219–227

² J. Schmidhuber, R. Huber, *Learning to Generate Artificial Fovea Trajectories for Target Detection In International Journal of Neural Systems*, 1991, vol. 2, no. 1–2, pp. 135–141

³ V. Mnih, N. Heess, A. Graves, K. Kavukcuoglu, *Recurrent Models of Visual Attention In Advances in Neural Information Processing Systems 27*, 2014, pp. 2204–2212

⁴ D. Bahdanau, K. Cho, Y. Bengio, *Neural Machine Translation by Jointly Learning to Align and Translate In International Conference on Learning Representations*, 2015

力。这使“怎样评分”和“允许读取哪些位置”成为可分别选择的设计；局部读取仍可以在窗口内部使用软权重，并不等于硬注意力⁵。同年，Xu 等的 Show, Attend and Tell 将基于内容的注意力用于图像描述：生成不同词时，语言解码器可以对不同图像区域分配权重，论文同时研究了软聚合与随机硬选择。被读取对象由源词变为图像区域，按当前需求选择信息的作用保持不变⁶。

自注意力：从读取另一序列到建立内部关系 注意力还可以用来联系同一序列中的位置。2016 年，Cheng 等在用于机器阅读的 LSTM 记忆网络中保存此前词元的表示，并让当前词元通过注意力读取这些记忆，建立序列内部关系。这种**序列内注意力**（intra-attention）是自注意力的一种早期实现，网络仍保留循环更新；因此，使用自注意力与取消循环结构是两个不同的设计选择⁷。

这段发展可以区分三个设计问题：硬选择与软聚合决定怎样读取信息，加性与点积形式决定怎样计算匹配，交叉注意力与自注意力决定读取来自哪里。评分方式、信息来源和读取范围可以组合；第 12.2.2 节将用查询、键和值统一描述这些角色，再展开 Transformer 采用的计算形式。

12.1.3 Transformer 的提出与演进

注意力机制使解码器可以反复读取源表示，但这些表示最初仍由循环网络产生。1997 年的 LSTM 通过记忆单元与控制门改善长距离信息的保留和梯度传递，更新仍沿时间进行⁸。2014 年，Sutskever 等用 LSTM 编码器—解码器进行序列转换，将输入压缩到固定维表示⁹。第 12.1.2 节介绍的软对齐进一步减轻了固定表示的瓶颈，循环递推却仍限制整段输入表示的并行形成。

2017 年，Vaswani 等在机器翻译中提出 Transformer：源端以自注意力形成上下文，目标端以因果自注意力形成前缀表示，再用交叉注意力读取源端。位置表示提供顺序，多头读取形成多组聚合，逐位置前馈层变换特征。这一设计把位置间的循环更新改为注意力读取与层间堆叠，为已知序列提供批量矩阵计算方式¹⁰。

⁵ T. Luong, H. Pham, C. D. Manning, *Effective Approaches to Attention-based Neural Machine Translation* In Proceedings of the 2015 Conference on Empirical Methods in Natural Language Processing, 2015, pp. 1412–1421

⁶ K. Xu, J. Ba, R. Kiros, K. Cho, A. Courville, R. Salakhudinov, R. Zemel, Y. Bengio, *Show, Attend and Tell: Neural Image Caption Generation with Visual Attention* In Proceedings of the 32nd International Conference on Machine Learning, 2015, pp. 2048–2057

⁷ J. Cheng, L. Dong, M. Lapata, *Long Short-Term Memory-Networks for Machine Reading* In Proceedings of the 2016 Conference on Empirical Methods in Natural Language Processing, 2016, pp. 551–561

⁸ S. Hochreiter, J. Schmidhuber, *Long Short-Term Memory* In Neural Computation, 1997, vol. 9, no. 8, pp. 1735–1780

⁹ I. Sutskever, O. Vinyals, Q. V. Le, *Sequence to Sequence Learning with Neural Networks* In Advances in Neural Information Processing Systems, 2014

¹⁰ A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, Ł. Kaiser, I. Polosukhin, *Attention Is All You Need* In Advances in Neural Information Processing Systems 30, 2017, pp. 5998–6008

后续发展又把网络结构与预训练目标结合。2018 年, GPT 用因果 Transformer 进行语言模型预训练, 再适配有监督任务¹¹。同年发布、2019 年发表于 NAACL 的 BERT 用双向编码器从被遮蔽的输入恢复词元, 形成可用于多种理解任务的表示¹²。2020 年发表的 T5 研究把任务统一为文本输入到文本输出, 采用编码器—解码器组织条件生成¹³。第 12.2.6 节将比较这些架构; 预训练数据和迁移范式由相关章节展开。

12.1.4 与 RNN/LSTM 的比较

与 RNN/LSTM 相比, 关键变化在于历史信息的组织方式。普通循环网络把过去压缩进固定宽度状态; LSTM 增加记忆与门, 改善保留方式, 但仍需经中间时间步传递。稠密自注意力保留逐位置表示, 让当前位置直接选择历史中的内容。它缩短了位置之间的结构路径, 也增加了要保存和读取的信息。若循环网络另外配有注意力和源表示存储, 就不再只有固定状态, 不能将其与纯循环网络混为一类。表 12.1 固定长度和宽度, 比较三种基础结构。

并行计算的条件是所需输入已经给定。训练自回归模型时, 真实目标序列已知, 可以一次送入移位后的目标, 并用掩码限制各位置读取; 生成时, 下一个词元尚未确定, 仍需根据已有前缀产生它, 再继续下一步。因此, Transformer 降低了网络内部沿位置更新的串行依赖, 并没有使标准自回归输出一次全部产生。

全局读取也有成本。设序列长为 n , 表示宽度为 d , 常规多头注意力的各头总宽度与 d 同阶, 一层自注意力的位置对计算需要 $O(n^2d)$ 次算术操作, 投影另需 $O(nd^2)$ 。直接保存各头权重需要 $O(hn^2)$ 个元素, 其中 h 为头数。与固定宽度的循环状态相比, Transformer 保存和读取了更多逐位置信息; 后文将区分减少连接、改变聚合公式和改善存储方式三种路线。适用场景包括文本、连续时间观测和图像块等可表示为向量序列的输入, 但顺序、局部关系和可见范围不能只靠“向量序列”这一形式自动获得。

比较维度	基础 RNN	LSTM	稠密 Transformer 自注意力
历史表示	固定宽度隐藏状态	隐藏状态与记忆单元	每层保留逐位置键和值
顺序来源	时间递推	时间递推及门控	位置表示与可见性约束
已知整段的计算	同层沿时间串行	同层沿时间串行	同层位置可并行, 层间依赖仍在
远位置的结构路径	经中间时间步, $O(n)$	经中间时间步, $O(n)$	允许直连时, 一层内 $O(1)$
单层整段算术量	$O(nd^2)$	$O(nd^2)$, 门增加常数	$O(n^2d + nd^2)$
生成时的历史存储	$O(d)$	$O(d)$	常规 KV 缓存为 $O(nd)$

表 12.1 固定输入及隐藏宽度同阶为 d 、序列长为 n 的结构比较。历史存储按单层、单样本统计, 省略训练激活和参数; Transformer 各头总宽度与 d 同阶。最短连接路径不保证实际依赖一定学会, 算术量也不直接等于运行时间。三者标准自回归生成时都逐步产生输出。

¹¹ A. Radford, K. Narasimhan, T. Salimans, I. Sutskever, *Improving Language Understanding by Generative Pre-Training*, OpenAI, 2018

¹² J. Devlin, M.-W. Chang, K. Lee, K. Toutanova, *BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding* In Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, 2019, pp. 4171–4186

¹³ C. Raffel, N. Shazeer, A. Roberts, K. Lee, S. Narang, M. Matena, Y. Zhou, W. Li, P. J. Liu, *Exploring the Limits of Transfer Learning with a Unified Text-to-Text Transformer* In Journal of Machine Learning Research, 2020, vol. 21, no. 140, pp. 1–67

12.2 网络结构

为看清各模块的职责，先用一段长度为 n 的输入建立共同记号。隐藏表示宽度为 d ，网络块数为 L ，第 l 个块后的矩阵为 $\mathbf{H}^{(l)} \in \mathbb{R}^{n \times d}$ ，按行存放各位置的列向量，即 $\mathbf{H}_{i,:}^{(l)} = (\mathbf{h}_i^{(l)})^\top$ 。括号上标表示层间更新编号，位置使用下标。这里讨论单个样本；批量计算另加样本维，并分别处理有效长度。

12.2.1 输入表示与位置编码

注意力接收向量，原始输入需要先转为统一宽度。文本中的**词元**（token）是分词系统采用的离散单位，可以是词、子词或符号。设词表大小为 v ，位置 i 的词元编号为 u_i ，嵌入矩阵为 $\mathbf{E} \in \mathbb{R}^{v \times d}$ ，则 $\mathbf{e}_i = (\mathbf{E}_{u_i,:})^\top$ 。同一词元共享同一行参数；经过网络后，隐藏表示还取决于它所在的上下文，不能把嵌入和上下文表示当成同一个对象。

若输入是 $\mathbf{x}_i \in \mathbb{R}^p$ 的连续观测，可以用 $\mathbf{e}_i = \mathbf{W}_{\text{in}}\mathbf{x}_i + \mathbf{b}_{\text{in}}$ 投影到 d 维，其中 $\mathbf{W}_{\text{in}} \in \mathbb{R}^{d \times p}$ 。图像可以先分为小块，再把每块的像素或前端特征展平并投影。离散嵌入、连续投影和图像块投影改变输入接口，后面的注意力仍读取向量；时间间隔、空间坐标或观测缺失等信息则须另行表示。

为什么 RNN 可以直接按顺序接收输入，Transformer 却要额外表示位置？递推式 $\mathbf{h}_i = f(\mathbf{h}_{i-1}, \mathbf{x}_i)$ 已经使第 i 步接收到“处理过前 $i-1$ 项”的状态，交换输入会改变后续计算。自注意力的共享投影只看到内容向量与内容匹配，矩阵的第几行并不会自动变成网络可用的特征。以“猫追狗”和“狗追猫”为例，若只有词元嵌入，两句话中同一个词元面对的内容集合相同；网络需要知道谁在动词之前、谁在之后，才能区分施事与受事。重复词元出现在不同位置时，也需要这种区别。

这一缺口可以用计算性质精确表达。以不含位置表示和顺序掩码的自注意力为例，对输入行施加置换矩阵 $\mathbf{P}$ ，查询、键、值也同步重排，得分矩阵变为 $\mathbf{PSP}^\top$ 。逐行 Softmax 随之重排，因此

$$\text{SA}(\mathbf{PH}) = \mathbf{P} \text{SA}(\mathbf{H}). \quad (12.1)$$

共享的逐位置前馈层和归一化保留这一等变性。若再做平均读出，整段输出便对重排不变；“猫追狗”和“狗追猫”可能因只有相同内容向量而无法区分。因果掩码也会引入顺序约束，所以式(12.1)的条件不能省略。但“只能看前面”与“相隔多远”是不同信息：掩码规定连接范围，并没有显式给出距离。某些因果网络可以利用边界与层间计算学习部分顺序，不能据此认为一般任务都无需位置表示。对于本来就是无序集合的输入，反而可能需要保留置换等变性，不应无条件添加任意编号。

位置编码（positional encoding）把元素所在位置或位置之间的关系加

入表示计算。最直接的做法为每个位置设置 $\mathbf{p}_i \in \mathbb{R}^d$ ，并令

$$\mathbf{h}_i^{(0)} = \mathbf{e}_i + \mathbf{p}_i. \quad (12.2)$$

这称为**绝对位置编码** (absolute positional encoding)：位置 i 本身有一个表示。可学习位置表与词元嵌入共同训练，正弦位置编码则按固定函数产生。相加要求维度一致，原始 Transformer 还对词元嵌入乘以 $\sqrt{d}$ ，以调整内容与位置的相对尺度。这个缩放属于具体参数化选择，并不是所有输入接口都必须使用的规则。

把这一步落到实际序列上，取“猫／追／猫”，暂把每个汉字当作一个词元；实际模型也可能采用子词等其他切分。两个“猫”查询同一行嵌入参数，因此位置 1 和 3 的内容向量相同。为便于手算，令嵌入宽度为 4，猫的嵌入为 $(0.20, -0.10, 0.40, 0.30)^\top$ ，追的嵌入为 $(0, 0.50, -0.20, 0.10)^\top$ 。这些嵌入是教学设定，不是从训练模型提取的结果。

图 12.1 把内容与位置分成两条计算路径。假设词表给“猫”和“追”分配的编号分别是 7 和 12，左路用词元编号 7, 12, 7 查嵌入表；右路从序列的先后顺序得到位置序号 1, 2, 3，并代入四维正弦位置向量 $\mathbf{p}_i = (\sin i, \cos i, \sin(0.01i), \cos(0.01i))^\top$ ，角度以弧度计。位置序号与词表编号不同，两个“猫”虽然查到同一个内容向量，仍会得到不同的位置向量。两路按对应坐标相加，输出形状保持为 3×4 。这里采用向量相加；若沿特征维拼接，两个四维向量会变成八维，属于另一种输入构造。第 12.4.1 节会解释这些频率如何推广到任意偶数宽度，以及如何改为表示相对距离。




图 12.1 序列“猫/追/猫”的输入构造。左路用词元编号查嵌入表，右路把位置序号代入正弦、余弦函数，两组 3×4 表示再逐元素相加。三个矩阵的行均按输入位置排列，每格是一个特征值。两个“猫”的内容相同、位置不同，输出的第 1 行与第 3 行因而不同。词元编号和嵌入为教学设定；位置向量按弧度计算，数值保留两位小数，最后一列看似相同是舍入所致。

位置向量并不是把位置编号 i 重复填满所有坐标。例如，后文第12.2.4节介绍的层归一化会减去一行的均值；若输入只加 $i\mathbf{1}$ 并立即按行归一化，这个位置常数就会被消去。不同频率或可学习坐标提供了更丰富的位置差异。相加也不意味着网络已理解语法，它只是让后续计算能够利用内容和位置的联合信息。

填充只是把不等长序列放入相同形状，不是新的观测。有效位置要有明确的集合或长度，填充位置在注意力、池化和损失中分别排除。若将多段独立文本装入同一矩阵，也需限制跨段读取，并明确位置编号的重置方式；矩阵中相邻不等于任务中连续。

12.2.2 注意力层

第12.1.2节已经介绍了注意力怎样根据当前需求读取信息。可以先把一次读取类比为查字典：手中待查的词是**查询** (query, Q)，字典里用于匹配条目的词头是**键** (key, K)，找到条目后读取的释义是**值** (value, V)。查询说明要找什么，键供查询比较，值提供读出的内容；键不是条目在数组中的整数下标。

注意力把这种查询推广为连续的软匹配。它不检查两个字符串是否完全相同，而用可学习投影产生查询、键和值向量，再由查询与键的连续相似度得分决定读取权重，对多个值软加权求和。投影参数随训练调整，匹配方式也随之改变。这里把输入固定为“猫／追／狗”：更新“追”的表示时，网络需要结合谁在追、追的是谁；更新“猫”时，所需的上下文组合又可能不同。同一个位置在读取别人和被别人读取时承担不同作用，查询与键用于评分，值用于输出，三者不需要具有相同含义。

设查询输入为 $\mathbf{H}_q \in \mathbb{R}^{n_q \times d}$ ，被读取输入为 $\mathbf{H}_s \in \mathbb{R}^{n_s \times d}$ 。暂省略偏置，单头投影为

$$\begin{aligned} \mathbf{Q} &= \mathbf{H}_q \mathbf{W}_q, & \mathbf{K} &= \mathbf{H}_s \mathbf{W}_k, \\ \mathbf{V} &= \mathbf{H}_s \mathbf{W}_v, \end{aligned} \quad (12.3)$$

其中 $\mathbf{W}_q, \mathbf{W}_k \in \mathbb{R}^{d \times d_k}$ ， $\mathbf{W}_v \in \mathbb{R}^{d \times d_v}$ ； $\mathbf{Q}$ 、 $\mathbf{K}$ 分别有 n_q 、 n_s 行和 d_k 列， $\mathbf{V} \in \mathbb{R}^{n_s \times d_v}$ 。若两侧宽度不同，只需分别调整投影的输入维度。下面分别说明评分公式、信息来源、可见范围与并行读取方式；这些维度可以组合，并非互斥的模型类别。

12.2.2.1 缩放点积注意力

缩放点积注意力 (scaled dot-product attention) 把所有查询与键的点积转为权重，再聚合值。令 $\mathbf{M} \in \mathbb{R}^{n_q \times n_s}$ 为固定掩码：允许读取时 $\mathbf{M}_{i,j} = 0$ ，禁

止读取时为 $-\infty$ 。一次前向计算为

$$\begin{aligned} \mathbf{S} &= \frac{\mathbf{Q}\mathbf{K}^\top}{\sqrt{d_k}} + \mathbf{M}, \\ \mathbf{A}_{i,j} &= \frac{\exp(\mathbf{S}_{i,j})}{\sum_{t=1}^{n_s} \exp(\mathbf{S}_{i,t})}, \\ \mathbf{Z} &= \mathbf{A}\mathbf{V}. \end{aligned} \quad (12.4)$$

$\mathbf{S}, \mathbf{A} \in \mathbb{R}^{n_q \times n_s}$, $\mathbf{Z} \in \mathbb{R}^{n_q \times d_v}$ 。第 i 行输出是 $\mathbf{z}_i = \sum_j \mathbf{A}_{i,j} \mathbf{v}_j$, 其中 $\mathbf{v}_j = (\mathbf{V}_{j,:})^\top$ 。Softmax 沿键的位置归一化, 每一行只在允许读取的位置上分配总量为 1 的权重; 各行独立归一化, 并不要求每列之和也为 1。

分母为什么是 $\sqrt{d_k}$, 而不是 d_k 或一个固定常数? 问题在于点积累积了 d_k 个乘积: 即使各坐标尺度没有变, 累加结果的波动也会随宽度增加。下面用一个初始化时的简化模型说明这种增长, 并把它与 Softmax 的梯度联系起来¹⁴。

从坐标方差得到缩放因子 暂时省略位置下标, 设 $\mathbf{q}, \mathbf{k} \in \mathbb{R}^{d_k}$ 相互独立, 各自坐标也相互独立, 且每个坐标均值为 0、方差为 1。令 $s = \mathbf{q}^\top \mathbf{k}$ 。对第 r 个乘积, 有

$$\mathbb{E}[q_r k_r] = \mathbb{E}[q_r] \mathbb{E}[k_r] = 0, \quad \mathbb{E}[(q_r k_r)^2] = \mathbb{E}[q_r^2] \mathbb{E}[k_r^2] = 1。$$

不同坐标乘积之间的协方差为 0, 因此

$$\begin{aligned} \mathbb{E}[s] &= \sum_{r=1}^{d_k} \mathbb{E}[q_r k_r] = 0, \\ \text{Var}(s) &= \sum_{r=1}^{d_k} \text{Var}(q_r k_r) + 2 \sum_{r < t} \text{Cov}(q_r k_r, q_t k_t) \\ &= d_k, \\ \text{Var}\left(\frac{s}{\sqrt{d_k}}\right) &= 1. \end{aligned} \quad (12.5)$$

标准差是方差的平方根, 所以点积的典型波动尺度为 $\sqrt{d_k}$ 。用它作分母, 可以消去由宽度引起的增长; 若除以 d_k , 方差反而变成 $1/d_k$, 宽度越大, 得分就越被压向 0。

得分尺度怎样影响 Softmax 将一行得分记为 $\mathbf{s}$ 、权重记为 $\mathbf{a} = \text{softmax}(\mathbf{s})$, 其导数为

$$\frac{\partial a_j}{\partial s_t} = a_j (\delta_{j,t} - a_t), \quad (12.6)$$

¹⁴ A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, Ł. Kaiser, I. Polosukhin, *Attention Is All You Need* In *Advances in Neural Information Processing Systems* 30, 2017, pp. 5998–6008

其中 $\delta_{j,t}$ 在 $j = t$ 时为 1, 否则为 0。若某个得分远大于其余得分, 对应权重接近 1, 其他权重接近 0, 这些导数都会很小。对于只有两个键的情况, 令 $\Delta = s_2 - s_1$, 则 $a_2 = 1/(1 + e^{-\Delta})$, 且 $\partial a_2 / \partial \Delta = a_2(1 - a_2)$; 当 $|\Delta|$ 很大时, 导数趋于 0。

例如, 取 $d_k = 64$, 若未缩放的两个得分为 $(0, 8)$, 第二个权重约为 0.9997, 对得分差的导数约为 0.00034; 除以 $\sqrt{64} = 8$ 后, 得分为 $(0, 1)$, 权重约为 0.7311, 对缩放后得分差的导数约为 0.1966。若比较反传到同一个原始点积差 r 的梯度, 还要计入缩放的导数:

$$a_2 = \frac{1}{1 + \exp(-r/\sqrt{d_k})}, \quad \frac{\partial a_2}{\partial r} = \frac{a_2(1 - a_2)}{\sqrt{d_k}}。$$

在本例 $r = 8$ 时, 该导数约为 $0.1966/8 = 0.02458$, 仍大于未缩放时的 0.00034。这组教学数值说明缩放如何缓解由维度放大造成的过早饱和; 它不保证每个输入的导数都增大, 也不要求所有注意力保持均匀。减去行最大值虽然能避免指数溢出, 却不改变得分差, 因此不能代替缩放。

上述方差结论有明确前提。训练后的查询、键可能相关, 坐标方差也未必为 1; 尤其自注意力的查询和键都来自输入表示, 独立假设只是一种尺度分析。 $1/\sqrt{d_k}$ 控制的是宽度带来的系统性变化, 并不保证任意训练阶段的得分方差恰好为 1。

示例 12.1 同一查询在不同可见范围内的读取 对“猫/追/狗”中第 2 个位置“追”发起的查询, 设 $d_k = 1$ 、 $q_2 = 1$, 三个词元的键依次为 $0, \log 2, 0$, 值依次为 $(1, 0)^T$ 、 $(0, 2)^T$ 、 $(1, 1)^T$ 。这些是投影后的教学数值, 不表示真实模型必然这样关注句子。三个缩放得分为 $(0, \log 2, 0)$, 取指数后为 $(1, 2, 1)$, 归一化得到权重 $(1/4, 1/2, 1/4)$ 。输出为

$$\mathbf{z}_2 = \frac{1}{4}(1, 0)^T + \frac{1}{2}(0, 2)^T + \frac{1}{4}(1, 1)^T = (1/2, 5/4)^T。$$

这个向量是“追”的新表示, 不是直接选出一个词。三个值都可能影响它, 贡献大小由各自权重决定。若改成因果读取, 当前位置尚不能看到“狗”, 得分变成 $(0, \log 2, -\infty)$, 权重相应变为 $(1/3, 2/3, 0)$, 输出为 $(1/3, 4/3)^T$ 。掩码改变了归一化的候选范围, 并不是算完权重后再把第三项直接清零。

图 12.2 先画出输入经三组参数投影得到查询、键和值, 再把“追”的读取拆成评分、归一化和加权求和。查询与键决定“读多少”, 值决定“读到什么”。值无需等于键, 注意力输出也不必等于任一输入值; 反向传播因此需要同时处理权重与值两条路径。




图 12.2 展开“追”的一次缩放点积注意力。输入分别经三组投影产生查询 Q 、键 K 和值 V ，三者各行依次对应猫、追、狗。突出显示的查询为 $q_2 = 1$ ，与全部键匹配得到三个得分。Softmax 产生权重后，下方三行分别列出各值向量的加权贡献，逐列求和得到 $\mathbf{z}_2^T = (0.50, 1.25)$ 。蓝格表示投影数据，紫格表示中间结果，青格表示输出； $d_k = 1$ 、 $d_v = 2$ ，数值均为教学设定。

12.2.2.2 自注意力：同一序列内部读取

上下文理解需要让一个输入位置结合其他输入位置。自注意力在式(12.3)中取 $\mathbf{H}_q = \mathbf{H}_s = \mathbf{H}$ ，查询、键和值都由同一组位置投影，得分矩阵为 $n \times n$ 。三组投影仍各有参数，所以“来自同一输入”不表示 $\mathbf{Q} = \mathbf{K} = \mathbf{V}$ 。图 12.3 中，“猫”“追”“狗”各发起一次查询，对同一组值分别加权。灰色双向线表示两个位置都可以向对方读取，但不要求两个方向的权重相等。红色箭头单独展开前例“追”的读取，起点是提供值的位置，终点是发起查询的位置。下方权重表按查询位置排列，第 2 行就是 $(0.25, 0.50, 0.25)$ 。若同一组键对应的另外两个查询取 $q_1 = \log_2 3$ 、 $q_3 = -1$ ，就分别得到第 1 行 $(0.2, 0.6, 0.2)$ 和第 3 行 $(0.4, 0.2, 0.4)$ 。查询不同，即使候选键值相同，读取也可以不同。整段输入可见时，所有有效位置可以互相读取，但允许读取不等于分配相同权重。




图 12.3 同一序列“猫/追/狗”上的自注意力。每个词元上方的四格条直接表示输入向量的特征坐标；这同一组表示分别投影为查询、键和值。灰色双向线表示两个位置可以互相读取，自环表示读取自身，两个方向的权重不必相等。红色箭头从值的来源指向“追”的查询位置，对应下方权重矩阵框出的第 2 行。三个查询各自归一化，图中未另画输出序列；数值为教学设定。

12.2.2.3 交叉注意力：从另一组表示读取

目标序列需要读取源序列时，双方长度和职责通常不同。交叉注意力(cross-attention)让 $\mathbf{H}_q$ 提供查询，另一组 $\mathbf{H}_s$ 提供键和值，得分矩阵为 $n_q \times n_s$ 。例如翻译目标当前位置用自己的状态提出查询，读取已编码的源句；输出

仍对应查询位置，而不是在两组输入之间各产生一份输出。以翻译“猫／追／狗”为例，图 12.4 同时展开两个已知目标输入位置 BOS 和 cat。BOS 位置的输出用于预测 cat，cat 位置的输出用于预测 chases；这两个目标状态产生两行查询，三个源编码状态产生三行键和值。源、目标长度不同，输出仍按目标查询排列，因此 $\mathbf{A}$ 为 2×3 ，而 $\mathbf{Z}$ 只有两行。

为了逐项算出一次交叉读取，取 $d_k = 1$ ，设目标投影后的查询为 $\mathbf{Q} = (0, 1)^\top$ ，源投影后的键为 $\mathbf{K} = (0, \ln 8, 0)^\top$ ，值沿用前例的三个二维向量。BOS 的三个得分都为 0，Softmax 给出 $(1/3, 1/3, 1/3)$ ；cat 的得分为 $(0, \ln 8, 0)$ ，取指数得到 $(1, 8, 1)$ ，归一化后为 $(0.1, 0.8, 0.1)$ 。两行分别乘以同一个 $\mathbf{V}$ ，得到 $\mathbf{z}_1 = (2/3, 1)^\top$ 和 $\mathbf{z}_2 = (0.2, 1.7)^\top$ 。后者仍属于 cat 的查询位置，而不是源词“追”的输出。数值为教学构造，不意味着翻译注意力必然逐词对齐。交叉注意力也可用于一种模态读取另一种模态；信息来源改变，不要求评分公式改变。




图 12.4 两条不同序列的交叉注意力。目标输入 BOS / cat 的状态投影为两行查询，源输入猫 / 追 / 狗的编码状态分别投影为三行键和值。得分与权重矩阵的行对应目标查询、列对应源词元，因此形状均为 2×3 ；权重矩阵乘以 3×2 的值矩阵后，输出为 2×2 。较深的单元格突出 cat 这一目标位置从查询、评分、归一化到输出的对应关系。 $d_k = 1$ ，所有投影数值均为教学设定。

12.2.2.4 因果注意力：只读取已知前缀

同一序列也可能包含尚不能用于当前预测的未来内容。**因果注意力** (causal attention) 通常指带因果掩码的自注意力，规定位置 i 只能读取 $j \leq i$ 的键值。图 12.5 把“猫／追／狗”的可见范围直接排成矩阵。更新“追”时，“狗”所在格被屏蔽；“追”的输出经后续计算用于预测“狗”，因此输入位置和预测标签正好错开一步。它改变候选集合，投影与聚合公式仍为式(12.4)。训练时即使整个真实序列已放进矩阵，也必须让每层都遵守这一限制；只屏蔽最后一层不能消除前层已经混入的未来信息。




图 12.5 “猫／追／狗”的因果自注意力。行对应查询位置，列对应被读取的键；红色格为可见位置的示例权重，浅灰叉号表示未来得分被设为 $-\infty$ 、权重为 0。“追”这一行经后续网络计算用于预测右侧的“狗”，却不能读取“狗”的输入，因而预测目标与当前输入错开一步；EOS 为结束符。下方展开框出的这一行：先屏蔽未来得分，再在可见位置间归一化为 (1/3, 2/3, 0)。数值沿用前例，均为教学设定。

填充掩码 (padding mask) 阻止有效查询读取填充键；因果掩码排除未来位置。两者可以合并，前者排除不存在的输入，后者排除预测时尚不可知的信息。每个参与计算的查询必须至少有一个有效键，否则整行 $-\infty$ 无法定义 Softmax。填充查询可以跳过，或允许它得到一个随后弃用的输出，不能让未定义值进入后续计算。因果掩码允许读取当前输入，这与预测下

一个目标的移位配合，才构成没有目标泄漏的生成模型。

12.2.2.5 多头注意力：并行形成不同的读取

单组权重把各值压缩为一个混合。**多头注意力** (multi-head attention, MHA) 使用 h 组投影分别读取，再把结果拼接：

$$\begin{aligned} \mathbf{Z}_a &= \text{Attention}(\mathbf{Q}_a, \mathbf{K}_a, \mathbf{V}_a), \\ \mathbf{C} &= \text{Concat}(\mathbf{Z}_1, \dots, \mathbf{Z}_h), \\ \text{MHA}(\mathbf{H}_q, \mathbf{H}_s) &= \mathbf{C}\mathbf{W}_o. \end{aligned} \quad (12.7)$$

头编号 $a \in \{1, \dots, h\}$, $\mathbf{C} \in \mathbb{R}^{n_q \times hd_v}$, $\mathbf{W}_o \in \mathbb{R}^{hd_v \times d}$ 。常取 $d_k = d_v = d/h$, 使总投影宽度固定。各头可以形成不同权重，输出投影再混合它们的特征；结构没有规定某头必须对应语法或语义，也不保证各头一定形成互补分工。固定 d 时增加头数会减小每头宽度，不能把它理解为免费增加表示容量。

图 12.6 展开同一序列上的两个注意力头。三个位置的表示只输入一次，再交给每个头各自的查询、键和值投影；不同的投影使各头能够形成不同的读取权重和值特征。每个头都输出三行向量，拼接时对齐相同位置，只扩展特征维。例如，“追”在两个头中的输出拼为 $[\mathbf{z}_{2,1}^T, \mathbf{z}_{2,2}^T]$ ，而不是把“追”与其他位置连接成更长序列。输出投影 $\mathbf{W}_o$ 再混合这些特征。多头既可用于自注意力，也可用于交叉注意力；每头还可以施加因果或其他掩码。把“多头”和“因果”并列为互斥选项，会遗漏常见的因果多头自注意力。




图 12.6 同一输入序列上的两个注意力头。每个头分别学习 $W_{q,a}$ 、 $W_{k,a}$ 和 $W_{v,a}$ ，独立完成评分、归一化和加权聚合，得到 Z_a 。黄色圆形 + 表示沿特征维拼接，两路输出的序列位置一一对齐；它不是残差相加。拼接矩阵 C 再经 W_o 投影，得到多头输出 Y 。各头的权重不直接平均，也没有预先指定的语法职责。

12.2.3 前馈层

注意力改变每个位置能读取什么，但读取结果还需转换为有用特征。**逐位置前馈网络**（position-wise feed-forward network, FFN）对每行单独使用同一组参数，在特征维上扩张、非线性变换，再恢复隐藏宽度：

$$\text{FFN}(\mathbf{H}) = \phi(\mathbf{H}\mathbf{W}_1 + \mathbf{1}\mathbf{b}_1^\top)\mathbf{W}_2 + \mathbf{1}\mathbf{b}_2^\top. \quad (12.8)$$

其中 $\mathbf{W}_1 \in \mathbb{R}^{d \times d_f}$ 、 $\mathbf{W}_2 \in \mathbb{R}^{d_f \times d}$ ， $\mathbf{b}_1 \in \mathbb{R}^{d_f}$ 、 $\mathbf{b}_2 \in \mathbb{R}^d$ ； $\mathbf{1}$ 为 n 维全 1 向量， ϕ 逐元素作用。原始结构取 $d_f = 4d$ 并使用 ReLU，其他结构可以采用第 8.1.2 节介绍的激活函数和不同中间宽度。

位置间共享不意味着各位置输出相同：输入行已经有不同内容和上下文。FFN 在这一层不额外交换位置，它把已有上下文中的特征组合成新表示；下一次注意力再依据这些表示进行读取。若去掉非线性，两次仿射映射可以合成一次，扩张宽度本身就失去了增加非线性组合的作用。

这一层的参数量约为 $2dd_f$ ，整段算术量为 $O(ndd_f)$ 。长序列的位置对计算可能占主导，短序列且 d_f 很大时，前馈层也可能占据大量计算和参数；分析 Transformer 代价时不能只看注意力矩阵。

12.2.4 残差连接与归一化

反复覆盖表示会使已有信息和梯度只能经过新增变换。**残差连接**（residual connection）把子层输出加到输入上，要求两者形状一致；输入保留一条直接传递路径，子层学习增量。注意力输出投影和 FFN 的维度恢复，也使这种相加可以在统一的 d 维空间进行。

不同位置的表示尺度还会影响点积和后续激活。**层归一化**（layer normalization, LayerNorm）在每个位置内部沿特征坐标计算均值和方差，不依赖其他样本或其他位置的统计量。对 $\mathbf{x} \in \mathbb{R}^d$ ，令

$$\begin{aligned} \mu(\mathbf{x}) &= \frac{1}{d} \sum_{k=1}^d x_k, & s^2(\mathbf{x}) &= \frac{1}{d} \sum_{k=1}^d (x_k - \mu(\mathbf{x}))^2, \\ \text{LN}(\mathbf{x}) &= \gamma \odot \frac{\mathbf{x} - \mu(\mathbf{x})\mathbf{1}}{\sqrt{s^2(\mathbf{x}) + \varepsilon}} + \beta. \end{aligned} \quad (12.9)$$

$\gamma, \beta \in \mathbb{R}^d$ 为可学习缩放和平移， $\varepsilon > 0$ 避免分母为零， $\odot$ 表示逐元素乘法。应用于矩阵时按行计算，各位置共享 γ, β 。所以一行的归一化本身不会读取未来位置，因果性仍由位置间模块的可见范围保证¹⁵。

原始 Transformer 把归一化放在残差相加之后，称为**后置层归一化**（post-

¹⁵ J. L. Ba, J. R. Kiros, G. E. Hinton, *Layer Normalization* In arXiv preprint arXiv:1607.06450, 2016

layer normalization, Post-LN)。一个编码器块为

$$\begin{aligned} \mathbf{U}^{(l)} &= \text{LN}_{l,1}(\mathbf{H}^{(l-1)} + \text{MHA}_l(\mathbf{H}^{(l-1)}, \mathbf{H}^{(l-1)})), \\ \mathbf{H}^{(l)} &= \text{LN}_{l,2}(\mathbf{U}^{(l)} + \text{FFN}_l(\mathbf{U}^{(l)})). \end{aligned} \quad (12.10)$$

实际训练还可在子层输出加入 Dropout，预测时关闭；这里省略它以突出确定性结构。**前置层归一化**（pre-layer normalization, Pre-LN）先归一化子层输入，再将子层输出加入原表示：

$$\begin{aligned} \mathbf{U}^{(l)} &= \mathbf{H}^{(l-1)} + \text{MHA}_l(\tilde{\mathbf{H}}^{(l-1)}, \tilde{\mathbf{H}}^{(l-1)}), \\ \tilde{\mathbf{H}}^{(l-1)} &= \text{LN}_{l,1}(\mathbf{H}^{(l-1)}), \\ \mathbf{H}^{(l)} &= \mathbf{U}^{(l)} + \text{FFN}_l(\text{LN}_{l,2}(\mathbf{U}^{(l)})). \end{aligned} \quad (12.11)$$

Pre-LN 通常在整个堆叠末尾再归一化，之后交给输出层。图 12.7 并列展开两种次序：Post-LN 在残差相加后归一化，Pre-LN 的跳跃路径则绕过归一化和子层；两者的学习性质将在第 12.4.5 节比较。每层通常使用自己的参数，位置间共享与层间共享是两种不同约定。




图 12.7 Post-LN 与 Pre-LN 编码器块的计算次序。底部矩阵的三行对应“猫/追/狗”，列示意特征维度，格子数不代表实际宽度。自注意力在行间交换信息，FFN 分别变换各行；圆形 + 表示逐元素残差相加。红色虚线概括反向梯度路径：Post-LN 的层间路径仍经过 LN，Pre-LN 则包含沿残差支路的恒等直通。省略 Dropout 与 Pre-LN 堆叠末尾的归一化。

12.2.5 输出和网络架构

相同网络块可以用于不同预测过程，架构选择取决于输出对应哪些位置，以及这些位置在预测时能读取什么。**编码器**（encoder）通常让有效输入位置双向读取，形成整段上下文表示；**解码器**（decoder）在生成场景中使用因果自注意力，根据已知前缀预测后续输出。这里的“解码器”既可指原始编码器—解码器中的目标网络，也可指单独使用的因果网络，是否有交叉注意力需要另行说明。

12.2.5.1 序列到分类或回归

整段评论分类需要把 n 行表示转为一个向量。若最终输出表示为 $\mathbf{H}$ ，有效位置集合为 V ，可以取 $\mathbf{r} = |V|^{-1} \sum_{i \in V} \mathbf{h}_i$ ，再经分类头计算 $\mathbf{p} = \text{softmax}(\mathbf{W}_c \mathbf{r} + \mathbf{b}_c)$ 。若有 c 类， $\mathbf{W}_c \in \mathbb{R}^{c \times d}$ ，目标为 $-\log p_y$ 。回归则用线性或受约束输出头形成数值，并选择与误差含义相符的损失。

另一种方式是在输入中加入专用读出词元，例如 CLS，使用其末层表示 $\mathbf{r}$ 。这个位置经注意力读取整段，参数和读出方式共同学习如何汇总；它并非未经训练就能概括全部内容。平均池化显式对位置等权，专用读出位置允许网络学习汇总，两者都要保证只读取任务允许的上下文。

12.2.5.2 同步序列到序列

词性或实体标签与输入位置对齐，可以对每行使用共享分类头，得到 $\mathbf{p}_i$ ，在有效监督位置上计算平均交叉熵。离线标注可以读取完整输入；在线预测则需要因果掩码，或明确规定可等待多少后续位置。若预测下一时刻数值，目标还需移位。输出逐位置对齐并不决定网络必须双向或单向，可见范围由实际预测条件确定。

12.2.5.3 异步序列到序列

机器翻译的目标长度和源长度不同。**编码器—解码器**（encoder-decoder）先形成源表示 $\mathbf{H}_s$ ，目标网络在每层执行因果自注意力、交叉注意力和 FFN。目标查询由该层已有的目标表示产生，键和值由最终源编码表示投影；源端填充掩码与目标端因果掩码分别约束两类读取。图 12.8 中，源表示供每个目标层重复读取，不必随着目标步重新编码。

给定源序列 x ，目标为 $y_1, \dots, y_m$ ，并将 EOS 计入目标，则条件分解为

$$p_{\theta}(y | x) = \prod_{i=1}^m p_{\theta}(y_i | x, y_{<i}),$$

$$\ell(x, y) = -\frac{1}{m} \sum_{i=1}^m \log p_{\theta}(y_i | x, y_{<i}).$$
(12.12)

θ 包含输入、网络块和输出层参数。**教师强制** (teacher forcing) 在训练时把真实目标前缀送入网络；目标输入是 BOS、 $y_1, \dots, y_{m-1}$ ，目标标签是 $y_1, \dots, y_m$ 。全段输入已知，各位置可以并行计算，因果掩码保证第 i 个输出没有读到待预测的 y_i 。

条件生成也可用单个解码器：把源输入、分隔符和移位目标组织成同一序列，通常只在目标预测位置计算损失。使用全因果掩码时，源位置也只能读取其前缀；使用前缀掩码时，源位置可互相读取，目标位置可读取全部源前缀和此前目标。两种方式都能定义条件生成，但形成的源表示和注意力范围不同，不能与独立编码器—解码器逐层等同。




图 12.8 将“猫／追／狗”翻译为“cat / chases / dog”的整网结构。每个长条表示作用于整段序列的一层， $\times L$ 表示重复堆叠；词元列保持位置对应。训练时右移的目标输入分别预测 cat、chases、dog、EOS。左侧最终源表示沿标出的 KV bus 供每个解码器层生成 K、V，Q 来自该层目标路径；不会把某个中间编码层与同编号解码层一一配对。省略层内残差、归一化与 Dropout。

12.2.5.4 序列续写与生成

单独的因果解码器省略源交叉注意力，将已有文本本身作为条件。对词元 $u_1, \dots, u_n$ ，从 BOS 开始预测时，联合概率为 $\prod_{i=1}^n p_{\theta}(u_i | u_{<i})$ 。若最终表示 $\mathbf{h}_i$ 对应第 i 个已输入词元，则下一词元概率为

$$\mathbf{p}_{i+1} = \text{softmax}(\mathbf{W}_{\text{out}}\mathbf{h}_i + \mathbf{b}_{\text{out}}), \quad (12.13)$$

其中 $\mathbf{W}_{\text{out}} \in \mathbb{R}^{v \times d}$ 。可令 $\mathbf{W}_{\text{out}} = \mathbf{E}$ 进行输入输出嵌入共享，但这会约束参数，并不是两个矩阵本来就具有相同职责。大词表投影还会产生 $O(dv)$ 的单位置计算。

生成从已知前缀开始，计算下一词元分布，按指定策略选择一个词元，将其加入输入，再继续，遇到 EOS 或最大生成长度停止。贪心选择只保证当前条件下的最大概率词元，不保证整段最优；采样改变输出分布。训练损失、预测时的选择策略和实际任务评价需分别说明。编码器适合已知完整上下文的理解，因果解码器适合按前缀生成，编码器—解码器使源与目标表示分开组织；这些对应关系仍受输入何时可见和计算预算约束。

12.2.6 常见 Transformer 架构

前面按输出形式组织了网络，这里进一步比较几种实际模型。同样面对“猫追狗”，BERT 可以补回被遮蔽的“追”，GPT 可以根据“猫追”续写“狗”，编码器—解码器则可以把整句翻译成另一种语言。它们共享注意力与前馈计算，但读取范围、监督位置和生成过程不同。以下架构图参考 Bishop 与 Bishop 第 12 章的分层表示：贯穿各个词元的长条表示作用于整段序列的一层，旁边的计算图展开该层内部的子层与残差。这样可以区分“词元之间怎样读取”和“网络层怎样堆叠”¹⁶。各图都把中文例子按词划分，以便观察对应关系；这种教学划分不代表某个模型实际采用的子词分词器，图中的词元是监督目标或示例生成结果。

¹⁶ C. M. Bishop, H. Bishop, *Deep Learning: Foundations and Concepts*, Springer, 2024

12.2.6.1 原始 Transformer：源与目标分开建模

翻译时，源句通常已经完整给定，目标句却需要逐词产生。这两个条件不同，原始 Transformer 使用两组网络分别处理：编码器双向读取源句，解码器因果读取已有译文，再通过交叉注意力查询源表示。原论文基础模型的编码器和解码器各有 6 个块，隐藏宽度 512，8 个注意力头，FFN 中间宽度 2048，采用正弦位置编码、ReLU 与 Post-LN¹⁷。

图 12.9 把“猫追狗”的翻译展开。训练时，解码器输入是右移的目标“BOS、cat、chases”，对应监督目标是“cat、chases、dog”。预测 dog 的目标位置可以读取 cat 和 chases，同时通过交叉注意力读取源句中的“狗”；后者属于已知条件，不是未来译文，因此不构成答案泄漏。推理时没有正

¹⁷ A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, Ł. Kaiser, I. Polosukhin, *Attention Is All You Need* In *Advances in Neural Information Processing Systems* 30, 2017, pp. 5998–6008

确译文可供右移，解码器把自己已经生成的词元作为后续输入。

这种组织可以一次编码源句，并在多个解码步骤中复用源表示，源端也能充分结合左右语境，适合输入和输出边界明确的翻译、摘要等任务。代价是需要维护两组网络和交叉注意力；当任务只是从一个前缀继续写下去时，单一路径的因果模型通常更直接。两者的成本仍取决于源长、目标长、网络宽度和层数，不能仅凭是否有两个堆栈判断哪一个一定更省计算。




图 12.9 原始 Transformer 基础模型的层内计算与条件生成。浅色框内的编码器块和解码器块各堆叠 6 次；图展开一个块，Add & Norm 表示残差相加后逐位置 LN。源端最终输出供每个解码器块的交叉注意力生成 K、V，目标路径提供 Q。三个目标输出是对应右移输入的监督标签，推理时逐步生成。省略 Dropout、嵌入缩放和各头内部投影。参考 Bishop 与 Bishop (2024) 图 12.9、12.19 与 12.20 的布局重绘，结构依据 Vaswani 等 (2017)。

12.2.6.2 BERT：利用左右语境形成表示

若目标是判断句意或标注每个词元，当前位置常常需要后文。BERT 保留双向编码器，并使用**遮蔽语言模型**（masked language model, MLM）预训练：先扰动部分输入，再从上下文恢复原词元。例如输入“猫 [MASK] 狗”时，被遮蔽位置必须结合“猫”和“狗”预测“追”。原始 BERT 还通过 CLS 位置的表示预测两个句段是否相邻，即下一句预测（next sentence prediction, NSP）。BERT Base 为 12 层、宽度 768、12 个头，Large 版本为 24 层、宽度 1024、16 个头；输入叠加词元、可学习位置和句段嵌入，块内使用 GELU 与 Post-LN¹⁸。

图 12.10 中，MLM 只在选中的位置接受词元监督；用于分类时，则可以在 CLS 表示上接任务头。原始训练并非把每个选中位置都替换为 [MASK]，还混合随机替换和保留原词，以减轻预训练输入与实际使用输入的差别。这里画出遮蔽分支，是为了突出双向上下文如何帮助恢复缺失内容。

双向读取使 BERT 适合在完整输入上做分类、抽取和序列标注；各位置表示可以在一次前向计算中并行形成。它的限制来自学习目标：MLM 没有直接给出 GPT 式的左到右联合概率，也没有定义下一步如何接着生成。把原始完整句子输入双向编码器，再用当前位置预测同一个词元，会给模型直接看到答案的机会；若要生成，需要另外设计目标和解码过程。

¹⁸ J. Devlin, M.-W. Chang, K. Lee, K. Toutanova, *BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding* In Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, 2019, pp. 4171–4186




图 12.10 BERT 的双向编码器与预测位置。每列的词元、位置、句段嵌入逐元素相加，本例同属句段 A；向量格条只示意特征维。每个长条是一整层双向自注意力与 FFN 计算，能够在所有有效词元之间交换信息，中间层省略。MLM 头在遮蔽位置恢复“追”，CLS 分类头用于任务适配；两者不要求同时使用。右侧展开一层的 Post-LN 与残差，省略输入归一化、Dropout 与 NSP 头。参考 Bishop 与 Bishop (2024) 图 12.18 的整序列布局重绘，输入与训练目标依据 Devlin 等 (2019)。

12.2.6.3 RoBERTa：改进双向编码器的预训练

BERT 的效果还取决于预训练方式，而不仅是网络拓扑。**RoBERTa** 保留 BERT 式双向编码器，主要改变训练配方：每次送入序列时重新抽取遮蔽位置，取消 NSP，使用更大的批次、更多文本和更充分的训练，并改用字节级 BPE 词表。图 12.11 展示动态遮蔽：同一句“猫追狗”在不同次训练中可以分别恢复“追”和“猫”，从而让模型接触不同的上下文恢复问题¹⁹。

RoBERTa 的意义是说明：保持核心结构不变，也能通过数据、目标和优化设置改善表示学习。与 BERT 相比，它不增加一种新的信息流，但预训练投入更大；论文中的收益属于整体训练方案，不能全部归因于取消 NSP 或动态遮蔽中的单个改动。两者在使用方式上仍然接近，都适合完整输入上的理解任务，也都需要额外设计才能作为自由续写模型。

¹⁹ Y. Liu, M. Ott, N. Goyal, J. Du, M. Joshi, D. Chen, O. Levy, M. Lewis, L. Zettlemoyer, V. Stoyanov, *RoBERTa: A Robustly Optimized BERT Pretraining Approach* In arXiv preprint arXiv:1907.11692, 2019




图 12.11 RoBERTa 对“猫追狗”的两次动态遮蔽。两组输入分别前向，使用同一套骨干参数，各长条只在所属样本内部进行双向读取；两次 MLM 监督分别恢复“追”和“猫”。词元与位置嵌入相加，中间层省略，右侧展开共用的 Post-LN 层。格条只示意特征维；[MASK] 采用教学记号，省略实际特殊词元、输入归一化与 Dropout。训练不使用 NSP。参考 Bishop 与 Bishop (2024) 图 12.18 的布局重绘，训练差异依据 Liu 等 (2019)。

12.2.6.4 GPT：因果解码器及其版本演进

续写时，模型只能依据已经出现的内容预测下一项。GPT 家族由这一任务发展而来；早期公开的 GPT-1、GPT-2 和 GPT-3 都采用只有解码器的组织，每个块包含因果自注意力与 FFN，没有独立源编码器，也没有连接源表示的交叉注意力。版本之间既有块内计算的调整，也有规模、训练目标与使用方式的变化，需要沿着这些具体对象比较。

GPT-1：建立预训练后微调的因果模型 初代 GPT 于 2018 年采用 12 层、宽度 768、12 个头的结构，配合可学习绝对位置、GELU 与 Post-LN；先用下一词元预测进行语言模型预训练，再针对下游任务微调。为便于与后续版本区分，这里称其为 GPT-1²⁰。

图 12.12 中，“猫”位置预测“追”，“追”位置预测“狗”。训练时三个位置可以一起计算，因为因果掩码已经阻止了未来信息进入各层表示；推理时则必须先选出“追”，才能把“猫追”作为下一步的前缀。把问题、示例或文档放在前缀中，后面接答案，就能沿同一条路径完成条件生成。

²⁰ A. Radford, K. Narasimhan, T. Salimans, I. Sutskever, *Improving Language Understanding by Generative Pre-Training*, OpenAI, 2018




图 12.12 GPT 的因果网络与下一词元监督。每列的词元与位置嵌入相加后，经过整序列网络层，再由 LM 头预测下一词元；“追”所在列只能读取“猫、追”，对应标签为“狗”。左侧红色虚线表示 LM 词表投影与输入词嵌入共享转置权重。右侧展开 GPT-1 的 Post-LN 层；GPT-2 与 GPT-3 改用 Pre-LN 并在堆叠末尾归一化。格条只示意特征维，省略 Dropout 与 KV 缓存。

这条因果路径使训练目标与逐词生成直接对应，条件和输出可以采用统一的文本接口。它也限定了表示的可见范围：某个早期位置看不到后文，不能直接等同于 BERT 的双向词元表示；生成长输出仍需要多个依赖步骤。用于分类时，因果模型可以在读完整段后的末位置作判断，也可以生成类别名称，但这与 BERT 在 CLS 上使用固定类别头的损失和输出空间不同。

GPT-2：调整归一化位置并扩大模型 GPT-2 保留因果解码器，将归一化从子层残差相加之后移到子层入口，形成 Pre-LN，并在整个堆栈末端增加归一化。这样的变化修改了深层残差路径中的计算顺序，具体梯度差异可结合第12.2.4节理解。GPT-2 还扩大模型和网页训练语料，进一步考察不更新参数时的零样本迁移。原论文最大配置为 48 层、宽度 1600、约 15 亿参数，上下文长度由 GPT-1 的 512 提高到 1024²¹。

²¹ A. Radford, J. Wu, R. Child, D. Luan, D. Amodei, I. Sutskever, *Language Models Are Unsupervised Multitask Learners*, OpenAI, 2019

GPT-3：扩大规模并交替使用两种注意力连接 GPT-3 沿用 GPT-2 的总体组织与 Pre-LN，但在不同层中交替采用稠密和局部带状稀疏注意力。前者允许当前位置读取全部已有前缀，后者只保留规定的局部连接；两者都遵守因果约束。最大的公开配置为 96 层、宽度 12288、96 个头、1750 亿参数，上下文长度 2048。论文系统研究了**上下文学习**，即把少量任务示例放入前缀，而不在该任务的推理阶段更新模型参数²²。

这一步同时涉及网络与使用方式：增加层数和宽度扩大了可学习参数，调整注意力连接改变了每层的信息路径，而在提示中提供示例改变的是当前输入。上下文学习不要求另添一种任务专用网络，也不能与通过梯度更新权重的微调混为一谈。

InstructGPT 与 GPT-3.5 阶段：让生成服从指令和对话 模型会续写文本，不等于它会按照用户意图完成任务。InstructGPT 在语言模型基础上加入人类示范的监督微调，再用人类偏好训练奖励模型并优化输出，使训练目标更贴近指令遵循²³。2022 年发布的 ChatGPT 则基于 GPT-3.5 系列模型进行了面向对话的微调。GPT-3.5 是模型系列名称，ChatGPT 是对话系统名称；这项演进主要说明后训练和交互方式的改变，不能据此推断它采用了一种新的、已完整公开的注意力拓扑²⁴。

GPT-4 与 GPT-4o：扩展输入输出模态 GPT-4 的技术报告公开了图像与文本输入、文本输出，以及下一词元预训练和人类反馈后训练等信息，但明确未披露模型规模和详细内部架构。GPT-4o 则进一步公开了文本、视觉与音频的端到端联合训练。因此，比较这些版本时，可以讨论输入输出模态和训练目标的变化，不能把未经公开的参数量、专家数量或位置编码画成确定的内部结构²⁵。

GPT-5 发布系统：在模型之间选择计算路径 2025 年 GPT-5 发布时，官方将其在 ChatGPT 中的形态描述为一个统一系统：路由器在快速响应模型与更深入的推理模型之间选择。这里的路由器选择的是整个模型；后文的混合专家模型（MoE）则在一个网络层内，为各词元选择少量计算分支。两者的作用层级不同，发布说明也不足以确定各模型内部的层数、头数或稠密／稀疏结构²⁶。

表 12.2 将各代变化对应到已经披露的对象。GPT-1 至 GPT-3 可以比较具体块结构与配置；后续公开材料更多描述后训练、模态和系统组织，能够支持的比较也相应有所不同。

²² T. B. Brown, B. Mann, N. Ryder, M. Subbiah, J. Kaplan, P. Dhariwal, A. Neelakantan, P. Shyam, G. Sastry, A. Askell, S. Agarwal, A. Herbert-Voss, G. Krueger, T. Henighan, R. Child, A. Ramesh, D. M. Ziegler, J. Wu, C. Winter, C. Hesse, M. Chen, E. Sigler, M. Litwin, S. Gray, B. Chess, J. Clark, C. Berner, S. McCandlish, A. Radford, I. Sutskever, D. Amodei, *Language Models Are Few-Shot Learners* In *Advances in Neural Information Processing Systems* 33, 2020, pp. 1877–1901

²³ L. Ouyang, J. Wu, X. Jiang, D. Almeida, C. L. Wainwright, P. Mishkin, C. Zhang, S. Agarwal, K. Slama, A. Ray, J. Schulman, J. Hilton, F. Kelton, L. Miller, M. Simens, A. Askell, P. Welinder, P. Christiano, J. Leike, R. Lowe, *Training Language Models to Follow Instructions with Human Feedback* In arXiv preprint arXiv:2203.02155, 2022

²⁴ OpenAI, *Introducing ChatGPT*, Nov. 30, 2022, URL: <https://openai.com/index/chatgpt/> (visited on 10/03/2026)

²⁵ OpenAI, *GPT-4 Technical Report* In arXiv preprint arXiv:2303.08774, 2023; OpenAI, *GPT-4o System Card*, OpenAI, 2024

²⁶ OpenAI, *Introducing GPT-5*, Aug. 7, 2025, URL: <https://openai.com/index/introducing-gpt-5/> (visited on 10/03/2026)

代表版本	已公开的主要变化	阅读这些变化时应保留的区别
GPT-1（2018）	因果解码器、Post-LN；12 层、宽 768；语言模型预训练后进行任务微调	预训练目标与下游任务监督可以不同
GPT-2（2019）	改用 Pre-LN 并增加末端归一化；最大约 15 亿参数；1024 词元上下文	零样本任务提示不需要再训练一个专用输出头
GPT-3（2020）	延续 Pre-LN；稠密与局部稀疏注意力交替；最大 1750 亿参数；2048 词元上下文	提示中的少样本示例不等于梯度微调
InstructGPT / GPT-3.5 阶段 (2022)	人类示范与偏好用于后训练；ChatGPT 采用对话交互	基座模型、后训练方法和对话产品分属不同层面
GPT-4（2023）	图像与文本输入，生成文本；内部架构细节未公开	多模态能力不提供确定参数量或专家数的证据
GPT-4o（2024）	文本、视觉、音频端到端联合训练	模态扩展不能直接还原为一张已知的逐层网络图
GPT-5 发布系统 (2025)	在快速响应与深入推理模型之间路由	系统级模型选择不等于层内词元级 MoE

表 12.2 GPT 家族的代表性演进。参数与上下文数字指相应原论文的配置，GPT-4 之后列出官方明确披露的能力或系统组织，不推测未公开的网络细节；表格也不用于比较当前产品的可用性。

12.2.6.5 T5：把不同任务组织成文本到文本

翻译生成另一种语言, 分类输出一个类别, 摘要输出较短文本; 这些任务可以共享“读入条件文本、生成目标文本”的接口。T5 (Text-to-Text Transfer Transformer) 使用编码器—解码器, 把任务说明和输入交给双向编码器, 由因果解码器生成答案并交叉读取条件。它保留原始 Transformer 的两条路径, 但采用相对位置偏置、Pre-LN 和简化的归一化; 原始基础 FFN 使用 ReLU²⁷。

T5 的代表预训练任务是恢复被删去的连续片段。图 12.13 把“猫追狗”变成“猫 $\langle S_1 \rangle$ 狗”, 解码器生成“ $\langle S_1 \rangle$ 追 $\langle S_2 \rangle$ ”。这些专用标记称为**哨兵词元** (sentinel token), 作用是标明缺失片段及其边界。一个标记可以代替多个连续词元, 因此目标长度可以变化; 与 BERT 相比, T5 将缺失内容作为一段序列生成, 不是在原输入的每个遮蔽位置独立接一个预测头。

这种接口使分类也能写成生成类别文本, 任务之间不必各自规定一种输出头; 源端双向理解与目标端因果生成的职责保持清楚。相应代价是仍要维护编码器、解码器与交叉注意力, 生成式分类还需要规定合法类别词及其读出方式。统一文本接口方便复用训练流程, 却不意味着所有任务的成本和评价方法也随之相同。

²⁷ C. Raffel, N. Shazeer, A. Roberts, K. Lee, S. Narang, M. Matena, Y. Zhou, W. Li, P. J. Liu, *Exploring the Limits of Transfer Learning with a Unified Text-to-Text Transformer* In Journal of Machine Learning Research, 2020, vol. 21, no. 140, pp. 1–67




图 12.13 T5 的片段恢复任务与整网结构。 $\langle S_1 \rangle$ 替代源句中被删去的片段，目标中的同名标记引出该片段， $\langle S_2 \rangle$ 标记恢复序列的结束；右侧输入已右移，START 表示解码起始符。每个长条是一整层，编码器最终输出供各解码层的交叉注意力生成 K、V。注意力内部使用相对位置偏置，输入不叠加绝对位置向量。省略层内残差、Pre-LN、Dropout 与末尾 EOS。参考 Bishop 与 Bishop (2024) 图 12.20 的布局重绘，结构与任务依据 Raffel 等 (2020)。

12.2.6.6 架构之间如何取舍

表 12.3 将比较标准固定为已知条件、输出过程与结构代价。对一个具体任务，先判断后文何时可见、结果是否需要逐步生成，再选择网络组织。BERT 与 RoBERTa 的主要差异位于预训练方案；原始 Transformer 与 T5 共享编码器—解码器组织，却采用不同的位置表示、归一化和任务目标。因此，“模型名称不同”和“信息流类型不同”不是同一回事。

代表模型	条件与读取规则	结构带来的便利	相应代价或使用边界
原始 Transformer	源双向；目标因果并交叉读取源	完整编码源句，生成时复用源表示	两组网络和交叉注意力；目标仍逐步产生
BERT	扰动输入内双向读取	一次形成利用左右语境的各位置表示	MLM 不直接定义自由续写；任务需要适配输出头
RoBERTa	与 BERT 同属双向编码	保持结构，改进预训练数据与优化方案	预训练投入增大；生成边界与 BERT 相似
GPT	单一路径因果读取	前缀与答案共享接口，直接学习逐词生成	早期位置不读后文；长输出需要多步解码
T5	条件双向；目标因果并交叉读取条件	文本到文本接口统一多种任务	双堆栈成本；类别文本等仍需规定读出规则

表 12.3 代表架构的优势与边界。比较的是信息流和任务接口，不是在不同参数量、训练数据与硬件下比较实测速度或任务分数。同一家族的后续版本还可能修改位置编码、归一化和前馈层。

架构规定了可计算的信息路径，训练数据决定模型见过什么，学习目标决定哪些行为受到奖励，解码与系统组织决定模型怎样被调用。判断两个模型的区别，需要把这些因素分别对应到具体机制，才能解释它们为何适合不同任务。

12.3 参数学习

嵌入、注意力投影、前馈层、归一化和输出层由同一预测目标联合学习。一个批次中的样本可以具有不同有效长度，损失只覆盖监督位置；按样本平均与按词元平均会给予长序列不同权重，需要与目标风险的定义一致。本节重点说明尺度设置和注意力求导，优化器、学习率调度及通用正则化由训练与泛化章节展开。

12.3.1 参数初始化

第8.2.1节的对称性打破和方差传播原则仍然适用，但 Transformer 还需同时控制内容嵌入、点积得分与残差流的尺度。输入嵌入可从零均值分布初始化，不同词元独立采样；如果内容项使用 $\sqrt{d}$ 缩放，初始方差应连同这一缩放考虑。可学习位置表也需要适当尺度，避免输入在尚未学习时被位置项完全主导。连续输入则应先明确量纲和训练数据归一化，再设置投影。

对不带激活的投影 $\mathbf{Y} = \mathbf{XW}$ ，若输入坐标方差为 s_x^2 ，权重独立、零均

值且方差为 s_w^2 ，输入宽度为 d_{in} ，简化计算给出输出坐标方差 $d_{\text{in}} s_w^2 s_x^2$ 。可用 Glorot 尺度兼顾输入输出宽度，或用与 d_{in}^{-1} 同阶的方差控制前向尺度；ReLU 前馈支路则可采用式(8.32)的思路。具体选择还受激活、门控和残差参数化影响，不能给所有投影照搬同一个数值方差。

查询与键的初始尺度直接影响 Softmax。若二者每坐标方差分别为 s_q^2, s_k^2 ，沿用坐标独立和零均值近似，缩放后点积方差为 $s_q^2 s_k^2$ 。因此，除以 $\sqrt{d_k}$ 只抵消宽度因素；过大的投影范数仍会使得分过尖。值与输出投影则决定注意力支路加入残差的大小。FFN 的第二次投影也位于残差支路末端，应与第一投影和非线性一起检查输出尺度。

深度增加时，多次相加可能持续放大残差流。若一个简化子层写为 $\mathbf{h}^{(l)} = \mathbf{h}^{(l-1)} + a_l \mathbf{f}^{(l)}$ ，且各增量与已有表示不相关、各坐标方差为 s_f^2 ，则增量方差之和为 $\sum_l a_l^2 s_f^2$ 。取 a_l 与 $L^{-1/2}$ 同阶可在这个近似下控制累积量；实际分支往往相关，还需检查梯度和归一化位置。缩小支路末端权重、显式残差缩放与可学习门控是不同参数化，后文会比较，不能把这个独立近似当成深网络稳定性的证明。

归一化的缩放和平移常分别初始化为 1 和 0；输出层按其输入宽度设置尺度。若输入输出共享嵌入，两处梯度会累积到同一参数，初始化也只执行一次。把整个投影都置零可能阻断上游学习：例如 $\mathbf{Q} = \mathbf{K} = \mathbf{0}$ 时，得分对查询和键的局部梯度都为零。少量支路末端置零可以作为特定设计使用，但必须检查哪些参数在初始步骤能够收到非零梯度。

12.3.2 反向传播

注意力的参数既影响“读取什么”，也影响“怎样评分”。为把两条路径分清，采用矩阵梯度记号 $\mathbf{G}_X = \partial \ell / \partial \mathbf{X}$ ，其形状与 $\mathbf{X}$ 相同，并以 Frobenius 内积定义微分 $d\ell = \langle \mathbf{G}_X, d\mathbf{X} \rangle_F$ 。从式(12.4)中单头的 $\mathbf{Z} = \mathbf{A}\mathbf{V}$ 开始，若下游给出 $\mathbf{G}_Z$ ，则

$$\mathbf{G}_V = \mathbf{A}^\top \mathbf{G}_Z, \quad \mathbf{G}_A = \mathbf{G}_Z \mathbf{V}^\top. \quad (12.14)$$

值梯度汇集所有查询对同一值的读取贡献；权重梯度比较不同值对当前输出变化的作用。即使注意力权重暂固定，值路径也会传递梯度，完整求导还需要继续沿得分路径回传。

对第 i 行，把有效权重写为列向量 $\mathbf{a}_i$ ，其 Softmax 雅可比为 $\text{diag}(\mathbf{a}_i) - \mathbf{a}_i \mathbf{a}_i^\top$ 。与该行的权重梯度相乘，得到

$$(\mathbf{G}_S)_{i,j} = \mathbf{A}_{i,j} \left((\mathbf{G}_A)_{i,j} - \sum_{t=1}^{n_s} \mathbf{A}_{i,t} (\mathbf{G}_A)_{i,t} \right). \quad (12.15)$$

被禁止的项取权重和得分梯度为零；这里是在有效集合上求导，而不是对无穷量作普通浮点运算。每行得分梯度之和为零，与 Softmax 对整行得分

加同一常数不变的性质对应。使某个值权重增加的作用，必须与同一行其他值的平均作用比较，不能把每个位置的权重独立更新。

示例 12.2 从聚合误差到评分误差 沿用示例 12.1 未加掩码的情形，令 $\ell = (\mathbf{z}_2)_2$ ，即只考察“追”的输出向量的第二坐标，上游梯度为 $(0, 1)^\top$ 。三个权重的梯度为 0, 2, 1，加权平均为 5/4，得分梯度因此为 $-5/16, 3/8, -1/16$ ，总和为零。值梯度则分别为 $(0, 1/4)^\top$ 、 $(0, 1/2)^\top$ 和 $(0, 1/4)^\top$ 。若最小化此目标，评分路径倾向于降低第二个值的权重，值路径还可以直接降低被读取的第二坐标；两种变化共同影响输出。

掩码固定时，对缩放点积继续求导可得

$$\mathbf{G}_Q = \frac{\mathbf{G}_S \mathbf{K}}{\sqrt{d_k}}, \quad \mathbf{G}_K = \frac{\mathbf{G}_S^\top \mathbf{Q}}{\sqrt{d_k}}. \quad (12.16)$$

查询梯度聚合相关键，键梯度聚合读取它的查询；固定因果掩码只删除禁止的贡献。若得分还包含可学习位置偏置，相应参数按其使用的所有位置对累积得分梯度。

式(12.3)的投影梯度为

$$\begin{aligned} \nabla_{\mathbf{W}_q} \ell &= \mathbf{H}_q^\top \mathbf{G}_Q, \\ \nabla_{\mathbf{W}_k} \ell &= \mathbf{H}_s^\top \mathbf{G}_K, \quad \nabla_{\mathbf{W}_v} \ell = \mathbf{H}_s^\top \mathbf{G}_V, \\ \mathbf{G}_{H_q} &= \mathbf{G}_Q \mathbf{W}_q^\top, \\ \mathbf{G}_{H_s} &= \mathbf{G}_K \mathbf{W}_k^\top + \mathbf{G}_V \mathbf{W}_v^\top. \end{aligned} \quad (12.17)$$

交叉注意力的两侧接到不同上游模块；自注意力的两侧是同一矩阵，所以查询、键、值三条输入梯度需要相加。加入投影偏置时，其梯度为对应矩阵梯度沿位置求和。共享词元嵌入也按词元编号把各出现位置的贡献相加。

多头输出若为 $\mathbf{Y} = \mathbf{C} \mathbf{W}_o$ ，则 $\nabla_{\mathbf{W}_o} \ell = \mathbf{C}^\top \mathbf{G}_Y$ ， $\mathbf{G}_C = \mathbf{G}_Y \mathbf{W}_o^\top$ 。按拼接的列范围拆开 $\mathbf{G}_C$ ，各头分别执行上述求导，再将共同输入的梯度求和。各头参数通常不同，不能把头梯度平均后只更新一组权重。

残差相加把同一上游梯度送入直接路径和子层路径。对 Pre-LN 子层 $\mathbf{y} = \mathbf{x} + F(\text{LN}(\mathbf{x}))$ ，列向量记号下有

$$\mathbf{g}_x = \mathbf{g}_y + \mathbf{J}_{\text{LN}}^\top \mathbf{J}_F^\top \mathbf{g}_y. \quad (12.18)$$

FFN 沿用前馈求导，LN 在一行内部耦合坐标。若归一化输出为 $\mathbf{y}$ ，令

$\hat{\mathbf{x}} = (\mathbf{x} - \mu\mathbf{1})/\sqrt{s^2 + \varepsilon}$ 、 $\mathbf{u} = \mathbf{g}_y \odot \gamma$ ，以横线表示坐标平均，则

$$\mathbf{g}_x = \frac{\mathbf{u} - \bar{u}\mathbf{1} - \hat{\mathbf{x}}\bar{u}\hat{\mathbf{x}}}{\sqrt{s^2 + \varepsilon}}。 \quad (12.19)$$

缩放和平移的梯度分别由 $\mathbf{g}_y \odot \hat{\mathbf{x}}$ 和 $\mathbf{g}_y$ 沿位置、样本累积。训练中若使用 Dropout，还需按前向使用的同一随机掩码回传。至此，输出损失可以经注意力的读取与评分、逐位置变换和残差路径，传到全部可训练参数；能求出梯度仍不意味着优化一定成功。

12.4 Transformer 的扩展

标准网络将输入表示、位置读取、特征变换和残差更新组合起来。扩展方法可以改变其中某个计算，也可以只改变同一计算的执行与存储方式。比较时需要说明目标：更合适的位置关系、更有选择性的表示、更少的位置对计算、更小的中间激活，或更紧凑的生成缓存。这些目标会影响不同资源，因而可以组合，也可能相互制约。

12.4.1 位置编码的扩展

顺序信息可以加到输入，也可以进入位置对评分。前者给每个位置一个表示，后者让读取直接依赖相对距离；旋转则提供了把位置变换嵌入点积的实现机制。下面固定内容投影，比较位置到底在哪里参与计算。

12.4.1.1 绝对位置编码

可学习位置表 $\mathbf{P} \in \mathbb{R}^{n_{\max} \times d}$ 直接提供式(12.2)中的 $\mathbf{p}_i$ ，参数量为 $n_{\max}d$ 。长度上限外没有对应行，即使扩充或插值，也需要解释新位置如何获得训练支持。固定正弦编码对偶数宽度 d 定义

$$\begin{aligned} (\mathbf{p}_i)_{2k+1} &= \sin(i\omega_k), \\ (\mathbf{p}_i)_{2k+2} &= \cos(i\omega_k), \quad \omega_k = 10000^{-2k/d}, \end{aligned} \quad (12.20)$$

其中 $k = 0, \dots, d/2 - 1$ ，向量坐标从 1 开始， i 采用本章从 1 开始的位置编号；改从 0 开始时需统一输入约定。不同频率使坐标随位置以不同速度变化，无需学习位置表，任意整数位置都可以求值。

图 12.14 把这个变化画成波形。为在同一位置区间内看清快慢，这里取 $d = 8$ ，只画 $k = 0, 1$ 对应的前四个坐标：两对角频率分别为 1 和 0.1 弧度/位置。它与图 12.1 的四维手算例采用相同公式，但宽度不同；四维例子的第二对频率是 0.01，不能把两组参数混用。每对正弦与余弦具有相同周期，彼此相差四分之一周期；高频坐标随位置较快振荡，低频坐标变化较慢。一个位置的编码要在同一横坐标处读取各维的幅值，而不是选择其中

一条曲线。




图 12.14 固定正弦编码中选定坐标随输入位置的变化。取 $d = 8$ ，上图为坐标 1、2 ($k = 0$)，下图为坐标 3、4 ($k = 1$)；两图横轴范围相同，幅值无量纲。实线为正弦，虚线为同频余弦，周期分别约为 6.28 和 62.83 个位置。连续曲线帮助观察波形，实际序列只在整数位置取值；本图仅示意选定维度，不是完整八维编码或训练结果。

对固定距离 Δ ，加法公式把 $\mathbf{p}_{i+\Delta}$ 写为 $\mathbf{p}_i$ 各坐标对的线性变换。这使相对位移在编码中有规律可循，但不意味着整个注意力只依赖相对距离。把内容和位置相加后，投影点积还包含内容与位置的交叉项；网络需要学习如何使用这些项。函数能在新位置求值，与预测能在训练长度外保持可靠，是不同结论。

12.4.1.2 相对位置向量与距离偏置

若任务更关心“相隔多远”而非“位于第几位”，可以直接让位置对得分依赖 $j - i$ 。**相对位置编码** (relative positional encoding) 为位置之间的关系提供表示。设 $\mathbf{r}_{j-i}^k \in \mathbb{R}^{d_k}$ 、 $\mathbf{r}_{j-i}^v \in \mathbb{R}^{d_v}$ 为距离对应的键和值修正，则一

种形式为

$$S_{i,j} = \frac{\mathbf{q}_i^\top (\mathbf{k}_j + \mathbf{r}_{j-i}^k)}{\sqrt{d_k}} + M_{i,j}, \quad (12.21)$$

$$\mathbf{z}_i = \sum_j A_{i,j} (\mathbf{v}_j + \mathbf{r}_{j-i}^v).$$

这里 $S_{i,j}, M_{i,j}, A_{i,j}$ 是对应矩阵元素的简写, $\mathbf{q}_i, \mathbf{k}_j, \mathbf{v}_j$ 是各行转置后的向量。键修正改变匹配, 值修正把距离信息带入输出。Shaw 等采用截断距离, 共享过远位置的相对向量; 这样限制参数数量, 也合并了某些距离差异²⁸。

若只需修改评分, 可以使用标量偏置 b_{j-i} , 将其加到缩放点积上。偏置表可按距离截断或分桶, 后者让一组距离共享参数; 它比每个距离存储一个向量更紧凑, 但表达形式也不同。**线性偏置注意力** (attention with linear biases, ALiBi) 在因果读取中采用

$$S_{i,j}^{(a)} = \frac{\mathbf{q}_{i,a}^\top \mathbf{k}_{j,a}}{\sqrt{d_k}} - m_a(i-j), \quad j \leq i, \quad (12.22)$$

其中 $m_a > 0$ 是第 a 头的预设斜率, 未来位置仍由掩码排除。距离越远, 扣除越多; 不同斜率提供不同距离偏好。它无需训练长度对应的位置表, 原论文在特定语言建模设置中检验了长度外推。这个结果依赖模型、数据与长度范围, 线性距离偏好也可能不符合需要精确远距离访问的任务²⁹。

回到“猫/追/狗”, 图 12.15 把相对位置写成可逐格检查的距离矩阵。“追”读取“狗”对应 $j-i=1$; 若整段句子在更长文本中同时后移 5 位, 距离仍为 $8-7=1$ 。ALiBi 进一步把距离变成得分修正: 图中“狗”读取三个位置时分别扣除 1.0, 0.5, 0, 之后才做 Softmax。图 12.1 是在输入上相加, 而这里是在每一对位置的评分上相加, 两个操作作用于不同对象。

²⁸ P. Shaw, J. Uszkoreit, A. Vaswani, *Self-Attention with Relative Position Representations* In Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 2 (Short Papers), 2018, pp. 464–468

²⁹ O. Press, N. A. Smith, M. Lewis, *Train Short, Test Long: Attention with Linear Biases Enables Input Length Extrapolation* In arXiv preprint arXiv:2108.12409, 2021




图 12.15 “猫/追/狗”的相对位置。左图行是查询位置 i 、列是键位置 j ，格内为 $j - i$ ，正负号区分左右方向。右图取“狗”为查询、斜率 $m = 0.5$ ，演示 ALiBi 如何修正教学得分并重新归一化；显示数值保留两位小数，真实计算使用未舍入值。

12.4.1.3 旋转位置编码

绝对位置向量加到输入上之后，点积中会出现内容与位置的交叉项。若希望直接控制点积中的相对位置关系，可以换一种构造：分别根据位置 i 、 j 变换查询和键，但要求变换后的点积只通过 $j - i$ 依赖位置。**旋转位置编码** (rotary position embedding, RoPE) 用旋转实现这一要求：位置决定旋转角度，两向量的相对角度进入点积³⁰。

为什么旋转能表示位移 先考虑二维向量。希望位置每增加 1，就施加同一个变换，而且连续移动 i 步再移动 j 步，应等价于移动 $i + j$ 步。平面旋转满足这种组合规律，还能保留向量长度。设每步旋转 ω 弧度；单位横轴旋转 θ 后变为 $(\cos \theta, \sin \theta)^\top$ ，单位纵轴变为 $(-\sin \theta, \cos \theta)^\top$ 。把它们作为两列，就得到

$$\mathbf{R}(\theta) = \begin{pmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{pmatrix}. \quad (12.23)$$

对尚未施加本层 RoPE 旋转的查询 $\mathbf{q}_i = (q_{i,1}, q_{i,2})^\top$ ，令

$$\tilde{\mathbf{q}}_i = \mathbf{R}(i\omega)\mathbf{q}_i = \begin{pmatrix} q_{i,1} \cos(i\omega) - q_{i,2} \sin(i\omega) \\ q_{i,1} \sin(i\omega) + q_{i,2} \cos(i\omega) \end{pmatrix};$$

键同样取 $\tilde{\mathbf{k}}_j = \mathbf{R}(j\omega)\mathbf{k}_j$ 。这里旋转的是投影后的查询和键，内容向量仍决定旋转前的方向和长度。

³⁰ J. Su, Y. Lu, S. Pan, A. Mur-tadha, B. Wen, Y. Liu, *RoFormer: Enhanced Transformer with Rotary Position Embedding* In arXiv preprint arXiv:2104.09864, 2021

从两个绝对角度推到相对位置 矩阵转置把旋转角取反。再利用三角函数的和角公式，逐项相乘可得

$$\begin{aligned} \mathbf{R}(\alpha)^\top &= \mathbf{R}(-\alpha), \\ \mathbf{R}(\alpha)\mathbf{R}(\beta) &= \mathbf{R}(\alpha + \beta), \\ \mathbf{R}(i\omega)^\top \mathbf{R}(j\omega) &= \mathbf{R}((j - i)\omega). \end{aligned} \quad (12.24)$$

令 $\Delta = j - i$ ，代入两向量的点积，有

$$\begin{aligned} \tilde{\mathbf{q}}_i^\top \tilde{\mathbf{k}}_j &= \mathbf{q}_i^\top \mathbf{R}(\Delta\omega) \mathbf{k}_j \\ &= (q_{i,1}k_{j,1} + q_{i,2}k_{j,2})\cos(\Delta\omega) \\ &\quad + (q_{i,2}k_{j,1} - q_{i,1}k_{j,2})\sin(\Delta\omega). \end{aligned} \quad (12.25)$$

这就把“相对”落到了具体公式：内容通过两个乘积组合保留下来，位置只以 Δ 出现。若保持内容向量固定，把 i 和 j 同时加上 c ，差值不变，点积也不变。这是位置变换本身的性质；改变整段上下文可能改变查询和键，不能据此断言整个模型的输出不变。

图 12.16 给出可手算的例子。取“追”的位置 $i = 2$ 、“狗”的位置 $j = 3$ ，并令 $\mathbf{q}_i = \mathbf{k}_j = (1, 0)^\top$ 、 $\omega = \pi/6$ 。旋转后

$$\begin{aligned} \tilde{\mathbf{q}}_i &= (1/2, \sqrt{3}/2)^\top, \quad \tilde{\mathbf{k}}_j = (0, 1)^\top, \\ \tilde{\mathbf{q}}_i^\top \tilde{\mathbf{k}}_j &= \sqrt{3}/2 = \cos((3 - 2)\pi/6). \end{aligned}$$

两个向量分别转过 60° 和 90° ，点积由 30° 的夹角决定。这里的频率为画图方便而选取；一般内容向量原本就有自己的夹角，旋转在其上叠加位置差带来的角度。

从二维构造完整注意力头 若 d_k 为偶数，将坐标按 $(1, 2), (3, 4), \dots, (d_k - 1, d_k)$ 两两配对。第 u 对使用频率 $\omega_u = 10000^{-2u/d_k}$ ，其中 $u = 0, \dots, d_k/2 - 1$ 。把各旋转块放在对角线上，定义

$$\mathbf{R}_i = \text{diag}(\mathbf{R}(i\omega_0), \dots, \mathbf{R}(i\omega_{d_k/2-1})).$$


各对坐标独立旋转，完整点积就是它们各自点积之和，因此二维推导逐块成立：

$$\begin{aligned} \tilde{\mathbf{q}}_i &= \mathbf{R}_i \mathbf{q}_i, \quad \tilde{\mathbf{k}}_j = \mathbf{R}_j \mathbf{k}_j, \\ \tilde{\mathbf{q}}_i^\top \tilde{\mathbf{k}}_j &= \mathbf{q}_i^\top \mathbf{R}_i^\top \mathbf{R}_j \mathbf{k}_j = \mathbf{q}_i^\top \mathbf{R}_{j-i} \mathbf{k}_j. \end{aligned} \quad (12.26)$$

随后仍按式(12.4)除以 $\sqrt{d_k}$ 、加掩码并做 Softmax。由于 $\mathbf{R}_i^\top \mathbf{R}_i = \mathbf{I}$ ，旋转保留查询和键的范数。实现只需逐坐标对计算正弦、余弦和乘法，不必构造稠密的 $d_k \times d_k$ 矩阵；也可以只旋转其中一部分坐标。本文按相邻坐标配对；其他配对方式须使向量坐标、投影参数与缓存的约定一致。

生成时怎样复用旋转结果 标准用法旋转查询与键，不旋转值。在后文介绍的 KV 缓存中，第 t 个位置到来时，只需计算 $\tilde{q}_t = R_t q_t$ 和 $\tilde{k}_t = R_t k_t$ ，将旋转后的键与原值 v_t 追加保存。新查询与旧键 $\tilde{k}_j$ 做点积，式(12.26)自然给出相对位移 $j - t$ ；已经旋转过的旧键无需再按当前步旋转。缓存的物理存储位置可以变化，编码使用的仍应是词元的逻辑位置。这种复用要求位置编号、旋转频率与位置缩放规则保持一致；若改变这些规则，旧缓存也需要相应转换或重算。

多频率提供了不同的角度变化速度，却不保证每个点积都随距离单调衰减。例如前述单位向量的得分是 $\cos(\Delta\omega)$ ，它会随距离振荡。RoPE 在新位置可以求值，预测仍可能遇到训练未覆盖的相位和距离分布；调整频率或位置尺度会改变读取规律，需要在预期长度范围重新检验。



$$\langle \tilde{q}_i, \tilde{k}_j \rangle = \|q_i\| \|k_j\| \cos(\Delta\theta)$$

本例为 $\cos(30^\circ) = \sqrt{3}/2$ ；同时平移不改变 $\Delta\theta$

图 12.16 RoPE 在一个二维坐标对中的作用。左图两个内容向量重合；右图“追”的查询和“狗”的键按各自位置旋转，夹角为 $(3 - 2)\omega = 30^\circ$ ，点积因此依赖相对位置。示例频率为 $\pi/6$ ，用于演示几何关系；实际模型对多个坐标对采用不同频率，并保留各自的内容向量。

绝对与相对描述的是位置关系，旋转描述的是注入机制，所以它们不是三个完全互斥的标签。可学习绝对表有显式长度参数，固定正弦和 RoPE 无需位置表，距离偏置由距离覆盖或斜率决定参数量；这些资源差异都不能单独推出长度外推保证。图像还需要保留二维位置，连续时间数据需要处理实际时间间隔，单一序列编号未必足够。

12.4.2 注意力机制的扩展

完整序列计算同时有 n 个查询；逐步解码通常只增加一个查询，但仍要读取历史键和值。**键值缓存** (key-value cache, KV cache) 保存每层已有位置的键和值，生成时只计算新位置的投影并追加。固定参数、位置编号和因

果掩码时，旧位置表示不依赖未来输入，所以其键值可以复用；如果前缀内容或可见规则改变，原缓存未必继续有效。

对 L 层、 h 头、每头 $d_k = d_v$ 、当前长度 n 的单序列，标准缓存有 $2Lnh d_k$ 个元素，字节量还要乘以每元素的存储字节数和批量大小。缓存省去重算历史投影与历史网络块，但新查询仍需读取 n 个键和值，其位置对算术量为 $O(nh d_k)$ 。将长度从 1 生成到 n 时，稠密注意力累计仍有平方量级的位置对读取。预填充（prefill）是一次处理已知前缀并建立缓存，逐步解码（decoding）则复用缓存产生后续内容；两者的并行规模和存储瓶颈不同。

12.4.2.1 支持不同信息来源与可见范围

交叉注意力改变键值来源，因果注意力改变允许的连接，两者可以同时出现于同一目标块。**前缀注意力**（prefix attention）让给定条件前缀内部互相读取，而目标位置读取前缀和此前目标；前缀不能读取待生成目标，否则缓存前缀就需要随着目标重新计算。图 12.17 固定“猫/追/狗/EOS”四个位置，对比三种掩码。前缀方案把“猫追”设为已知条件，两位置内部可以互读；生成“狗”时可以读取这段条件，而“狗”的信息不能反向进入已缓存的条件表示。掩码表达实际已知信息，不应只按模型名称选取。



图 12.17 四个位置的读取范围。行表示查询位置 i ，列表示键位置 j ，着色格允许读取，带叉白格禁止读取。左为全部有效输入间的双向读取，中为 $j \leq i$ 的因果读取，右为前两个位置构成条件前缀的读取：前缀内部双向，目标读取全部前缀与截至当前位置的目标输入。目标输入已移位，因此读取当前输入不等于读取当前待预测标签。

12.4.2.2 优化动态信息选择：门控注意力

Softmax 每行必须把总权重 1 分配给可见值，即使这些值都不适合当前更新。**门控注意力**（gated attention）增加一个输入相关的控制量，调节特征或聚合结果的通过程度。例如，对第 a 头在位置 i 的结果，可以令

$$\mathbf{g}_{i,a} = \sigma(\mathbf{W}_{g,a}^\top \mathbf{h}_i + \mathbf{b}_{g,a}), \quad \tilde{\mathbf{z}}_{i,a} = \mathbf{g}_{i,a} \odot \mathbf{z}_{i,a}, \quad (12.27)$$

其中 $\mathbf{W}_{g,a} \in \mathbb{R}^{d \times d_v}$ ，Sigmoid 门与头输出同宽。每头一个标量门则把整头共同缩放。注意力权重选择“从哪些位置读取”，输出门决定“这次读取

的哪些特征应通过”，两者作用对象不同。

门也可置于值投影之后或最终输出投影之后，这些位置通常不等价。值门改变不同来源的内容，查询相关的输出门改变接收端结果。Qiu 等比较了门的位置和粒度，并在所测试的大语言模型配置中观察到聚合后 Sigmoid 门对训练与表示行为的改善；这些实验不能提升为任意架构的稳定性保证。逐坐标门增加非线性性和参数，也要考虑饱和造成的梯度减弱³¹。

图 12.18 接着使用“追”的聚合结果 $(0.5, 1.25)^T$ 。若当前表示生成的门为 $(0.2, 0.8)^T$ ，逐坐标相乘得到 $(0.1, 1.0)^T$ ，分别保留第一维的 20% 与第二维的 80%。位置权重在此前已经完成归一化，这里控制的是混合后的特征，不再重新分配三个来源词元的概率。门接在输出上，不会删除键值缓存或减少标准点积的连接数。




图 12.18 以“追”为查询的聚合后门控。左支路从整段序列读取内容，右支路仅由当前词元表示产生 Sigmoid 门。教学数值中，聚合结果 $(0.5, 1.25)$ 与门 $(0.2, 0.8)$ 逐坐标相乘，得到 $(0.1, 1.0)$ 。门控制的是输出特征，而不是三个来源位置的概率；图中固定一个头并省略头索引、多头拼接和输出投影，数值并非训练测量。

³¹ Z. Qiu, Z. Wang, B. Zheng, Z. Huang, K. Wen, S. Yang, R. Men, L. Yu, F. Huang, S. Huang, D. Liu, J. Zhou, J. Lin, *Gated Attention for Large Language Models: Non-linearity, Sparsity, and Attention-Sink-Free* In arXiv preprint arXiv:2505.06708, 2025

12.4.2.3 降低位置连接的计算量：稀疏注意力

稀疏注意力 (sparse attention) 只计算保留的连接。例如每个位置读取 w 个窗口位置，再加少量全局位置，若各头保留连接总数为 e_{att} ，评分和聚合需要 $O(e_{\text{att}}(d_k + d_v))$ 算术操作，权重存储为 $O(e_{\text{att}})$ 。窗口大小和全局连接数固定时，连接数随 n 线性增长；若窗口本身随 n 增长，则不能称为相同的线性代价。Sparse Transformer 采用特定稀疏分解，使连接数达到

$O(n\sqrt{n})$ 量级, 说明“稀疏”并不自动等于 $O(n)$ ³²。

删除连接也改变传播范围。只有窗口连接时, 一层无法读取窗口之外的信息, 跨层传播可扩大范围, 却增加依赖路径长度; 全局位置使远处信息有较短通路, 但也可能形成汇总瓶颈。连接模式需要与任务所需信息匹配, 而不是仅由稀疏比例判断。

12.4.2.4 降低聚合计算量: 线性注意力

线性注意力 (linear attention) 把位置对核改写为有限维特征内积, 以改变聚合次序。设 $\phi(\mathbf{q}), \phi(\mathbf{k}) \in \mathbb{R}^r$, 内积非负且分母为正, 则可定义

$$\begin{aligned} \mathbf{T} &= \sum_{j=1}^n \phi(\mathbf{k}_j) \mathbf{v}_j^\top, & \mathbf{b} &= \sum_{j=1}^n \phi(\mathbf{k}_j), \\ \mathbf{z}_i^\top &= \frac{\phi(\mathbf{q}_i)^\top \mathbf{T}}{\phi(\mathbf{q}_i)^\top \mathbf{b}}. \end{aligned} \quad (12.28)$$

$\mathbf{T} \in \mathbb{R}^{r \times d_v}$ 和 $\mathbf{b} \in \mathbb{R}^r$ 先汇总键值, 再被所有查询读取。除特征映射和输入输出投影外, 单头算术量为 $O(nrd_v + nr)$, 中间汇总存储为 $O(rd_v + r)$; 这里“线性”指固定 r, d_v 时对 n 线性, 不是整个网络对输入为线性函数。保存所有位置的激活和训练梯度还需额外存储。

因果读取把上述和限制到 $j \leq i$, 得到 $\mathbf{T}^{(i)} = \mathbf{T}^{(i-1)} + \phi(\mathbf{k}_i) \mathbf{v}_i^\top$ 、 $\mathbf{b}^{(i)} = \mathbf{b}^{(i-1)} + \phi(\mathbf{k}_i)$ 。它可用固定大小的状态逐步生成, 也可在整段输入上做前缀扫描。Katharopoulos 等给出了这类计算与循环形式的联系; 固定维特征通常改变标准 Softmax 注意力的核, 或者对它作近似, 不能仅靠乘法结合律把任意 Softmax 原样变为固定维线性注意力³³。

12.4.2.5 压缩位置交互表示: 低秩注意力

低秩注意力 (low-rank attention) 用较小的交互表示代替全部位置。例如 Linformer 在位置维上用 $\mathbf{E}_k, \mathbf{E}_v \in \mathbb{R}^{r \times n}$ 分别压缩键和值, 形成 $\bar{\mathbf{K}}, \bar{\mathbf{V}}$, 再计算 $n \times r$ 的注意力。固定各头配置时, 位置压缩、评分和聚合的量级可降为 $O(nr(d_k + d_v))$ 。它依赖低秩近似是否适合输入, 并改变了可读取的表示³⁴。

位置维的压缩若混入未来键值, 给压缩后的矩阵简单添加三角掩码不能消除泄漏; 因果用法必须另行设计。压缩矩阵还可能绑定最大长度, r 若为保持精度随 n 增长, 实际复杂度也随之改变。减少连接、改变核与压缩位置分别牺牲不同结构自由度, 应该在相同任务和有效长度下比较。

图 12.19 把三条路线放回同一句“猫在院里追狗”, 按字分成 6 个位置。(a) 只保留当前位置及其左右邻居, 把 36 个位置对减到 16 个; “追”这一行可以读取“里、追、狗”, 却不能在本层直接读取“猫”。(b) 为键特征和值设置可手算的二维数值。六项外积累加为 $\mathbf{T} = \begin{bmatrix} 6 & 3 \\ 3 & 6 \end{bmatrix}$, 键特征相加为

³² R. Child, S. Gray, A. Radford, I. Sutskever, *Generating Long Sequences with Sparse Transformers* In arXiv preprint arXiv:1904.10509, 2019

³³ A. Katharopoulos, A. Vyas, N. Pappas, F. Fleuret, *Transformers Are RNNs: Fast Autoregressive Transformers with Linear Attention* In arXiv preprint arXiv:2006.16236, 2020

³⁴ S. Wang, B. Z. Li, M. Khabsa, H. Fang, H. Ma, *Linformer: Self-Attention with Linear Complexity* In arXiv preprint arXiv:2006.04768, 2020


$\mathbf{b} = (4, 4)^\top$ ；查询特征 $(1, 1)^\top$ 因而得到 $(9/8, 9/8)^\top$ 。这里各位置共同贡献一个固定大小的状态，查询再从状态读取。

(c) 则直接压缩位置：教学投影把前三个位置、后三个位置分别取平均，形成两个键值槽。所有 6 个查询仍各有一行，但每行只向两个槽评分。图中为便于核对令 $\mathbf{E}_k = \mathbf{E}_v = \mathbf{E}$ ；Linformer 的投影可以学习，也不必采用局部平均。这三幅图分别改变连接、核与可读取的表示，不能仅凭矩阵变小就认为保留了同一种注意力。

(a) 稀疏：只保留邻近位置对



(b) 线性：先汇总键值，再让查询读取



(c) 低秩：把 6 个键值位置压成 2 个槽




图 12.19 三条效率路线的具体读法，序列均为“猫／在／院／里／追／狗”。(a) 着色格保留相邻位置的连接，紫框为查询“追”；白格被删除。(b) 给定教学键特征和值后，先累加外积和特征，再对查询归一化，数值由式(12.28)复核。(c) 示例投影把 6 个位置压成 2 个槽，右侧每行表示一个查询对两槽评分，颜色只表示存在连接。所有数值及压缩权重均为教学设定；三种方法并非对同一 Softmax 结果的等价改写。

12.4.2.6 优化中间存储与访存：FlashAttention

前面三条路线改变了读取规则或公式。**FlashAttention** 保留标准稠密注意力的数学结果，通过分块计算和在线归一化，避免把完整得分、概率矩阵写入大容量显存。它利用较小的片上存储反复处理查询和键值块，让数据读取与中间结果的存储更紧凑；反向传播再按需要重算部分块，而不是保存全部概率³⁵。

理解在线 Softmax 可以只看一个查询。已处理的键集合上，维护最大得分 m 、归一化分母 $s = \sum_j \exp(S_j - m)$ 和未归一化输出 $\mathbf{u} = \sum_j \exp(S_j - m)\mathbf{v}_j$ 。新键块集合为 B ，块内最大值为 m_B ，更新为

$$\begin{aligned} m' &= \max(m, m_B), & c &= \exp(m - m'), \\ s' &= cs + \sum_{j \in B} \exp(S_j - m'), \\ \mathbf{u}' &= c\mathbf{u} + \sum_{j \in B} \exp(S_j - m')\mathbf{v}_j. \end{aligned} \quad (12.29)$$

旧统计乘以 c ，是在新最大值下重新表达同一批指数。遍历全部有效块后，输出为 $\mathbf{u}/s$ 。初始为空时直接用第一个非空有效块建立统计，避免在全被掩码的块上做 $-\infty - (-\infty)$ 。


沿用示例 12.1，先处理得分 0， $\log 2$ ，得到 $m = \log 2, s = 3/2, \mathbf{u} = (1/2, 2)^\top$ ；再加入得分 0 和值 $(1, 1)^\top$ ，得到 $s' = 2, \mathbf{u}' = (1, 5/2)^\top$ ，仍输出 $(1/2, 5/4)^\top$ 。分块没有把不同块分别归一化后简单求和，而是维护全局共同分母。

在固定头数和宽度下，FlashAttention 把需要保存的注意力中间量从平方规模降到线性规模，实际训练还需保存其他模块激活。稠密位置对仍然存在，算术量仍为 $O(n^2d)$ ；浮点运算顺序改变，结果可能有舍入差异。“精确”表示没有另引入稀疏或核近似，不表示逐位比特相同。速度收益依赖块大小、硬件和输入形状，访存优化不能直接改写为算术复杂度降低。

图 12.20 对比“保存整个中间矩阵”与“算完一块就合并”。上图突出显示“追”这一查询的得分行和概率行；下图先读“猫、追”，再读“狗”，把前述数值示例逐步展开。第二块接着更新同一组 $m, s, \mathbf{u}$ ，因此最终分母覆盖所有键；它并没有把两次局部 Softmax 结果直接相加。对其他查询块重复这一过程，就能得到完整输出，而无需让完整得分、概率矩阵在大容量显存中落地。

³⁵ T. Dao, D. Y. Fu, S. Ermon, A. Rudra, C. Ré, *FlashAttention: Fast and Memory-Efficient Exact Attention with IO-Awareness* In arXiv preprint arXiv:2205.14135, 2022

(a) 常规实现：保存完整中间矩阵



(b) FlashAttention：分块计算并更新统计




图 12.20 FlashAttention 保留稠密注意力结果，改变中间结果的存储与合并方式。红底表示容量大但较慢的 HBM，蓝底表示容量小但较快的片上 SRAM。上图的常规实现把完整 S, A 写回 HBM；下图按块在 HBM 与 SRAM 间搬运，只在片上保存当前块和在线统计 $m, s, \mathbf{u}$ ，最终仍得 $(1/2, 5/4)^T$ 。数值为教学设定；图只展开查询“追”，省略反向重算细节。




图 12.21 常规实现与 FlashAttention 的 HBM 中间量对比。柱高只表示量级差异，不是硬件实测：常规路径显式保存两个 $n \times n$ 矩阵，FlashAttention 避免它们完整落地，只保留 $\Theta(nd)$ 规模的序列张量及分块统计。它仍计算稠密位置对，算术量没有因此从平方降为线性；真实 I/O 还依赖片上容量和块大小。

12.4.2.7 减少 KV 缓存容量与读取带宽：MQA 与 GQA

解码时，标准 MHA 为每头保存一套键和值。**多查询注意力**（multi-query attention, MQA）保留多个查询头，让它们共享一组键值；**分组查询注意力**（grouped-query attention, GQA）将 h 个查询头分组，共享 g 组键值，其中 $1 \leq g \leq h$ 。设映射 $\rho(a)$ 把查询头 a 分到键值组，则该头读取 $\mathbf{K}_{\rho(a)}, \mathbf{V}_{\rho(a)}$ ，仍有自己的一行 Softmax 和输出。

当 $d_k = d_v$ 时，缓存元素数由 $2Lnhd_k$ 变为 $2Lngd_k$ ；MQA 对应 $g = 1$ ，MHA 对应 $g = h$ 。例如 $L = 24$ 、 $n = 4096$ 、 $h = 16$ 、 $d_k = 64$ 、每元素 2 字节的单序列 MHA 缓存约为 384 MiB， $g = 4$ 的 GQA 约为 96 MiB，MQA 约为 24 MiB。这个教学计算只统计键值，不包含权重、其他激活和内存分配开销。

图 12.22 固定 3 个历史位置“猫、追、狗”和 4 个新查询头，逐项数缓存中的键值对。MHA 为每头保留 3 对，共 12 对；两组 GQA 保留 6 对；MQA 只保留 3 对。图中的“猫”在 MHA 中出现 4 次，表示同一历史位置经过 4 组不同投影后产生的 4 对键值，并不是把同一个向量机械复制 4 份。共享后，不同查询仍分别与所读键匹配，所以可能得到不同的概率和输出。




图 12.22 相同历史序列在 MHA、GQA 和 MQA 中的缓存布局。每个带词元名的小格代表该位置在一组投影下的一对键和值；大框是一整组历史缓存，箭头指向读取它的查询头。4 个查询头分别使用 4 组、2 组或 1 组键值时，缓存为 12、6 或 3 对，右上容量条相对于 MHA 依次为 100%、50% 和 25%。共享发生在键值表示及其存储上，各查询头仍独立计算注意力权重。图只计一层的一条序列，不含当前新位置追加的缓存。

Shazeer 提出 MQA 以减少增量解码的键值访存, Ainslie 等用 GQA 提供共享程度与质量之间的中间选择。共享减少了键值投影和缓存自由度, 但查询头仍需分别匹配; 算术量并不按 g/h 等比例减少。缓存读取若能在实现中复用, 带宽需求才会相应改善, 质量和速度都需要在给定模型与硬件上评价³⁶。GQA 还可由已有多头模型进行参数转换并继续训练, 转换本身并不保持原模型的所有输出³⁷。

12.4.2.8 提高 KV 缓存内存利用率: PagedAttention

缓存容量之外, 还存在分配问题: 不同请求的长度持续增长, 为每个请求预留连续最大空间会留下空闲区域, 共同前缀还可能被多次保存。**分页注意力 (PagedAttention)** 把缓存划分为固定容量块, 用块表把序列的逻辑位置映射到实际存储位置; 序列增长时追加块, 而不要求整段缓存连续。共同前缀可以引用同一批块, 分叉后按需要复制, 避免直接修改仍被其他请求读取的数据³⁸。

若每块容纳 b 个位置, 长度 n 需要 $\lceil n/b \rceil$ 块, 最后一块的内部空余少于 b 个位置, 另有块表和管理开销。原来连续存储中的外部碎片和重复前缀可由此减少, 但真实键值元素数没有凭空消失。PagedAttention 改变缓存寻址和共享, MQA/GQA 改变键值组数, FlashAttention 改变注意力中间结果的执行方式; 三者处理不同问题, 可在兼容实现中组合。块调度、并发服务和硬件算子的细节由系统卷展开。

图 12.23 用两个请求演示块表的作用。为便于说明, 把“请/解释/注意力/机制”和“请/解释/位置/编码”各视为 4 个词元, 每块放 2 个位置。本图的词元位置与逻辑块均从 0 编号。A 按物理块 $3 \rightarrow 1$ 读取, B 按 $3 \rightarrow 4$ 读取, 两者共享前缀块 3, 物理块 2 仍可供其他请求使用。读取 A 中位置 $i = 1$ 的“解释”时, 逻辑块为 $\lfloor 1/2 \rfloor = 0$, 块内偏移为 1; 查 A 块表索引 0 得到物理块 3, 再从其中的偏移 1 取出键和值。逻辑块号、物理块号和词元位置承担不同职责, 移动物理存储不会改变词元的位置编码。

³⁶ N. Shazeer, *Fast Transformer Decoding: One Write-Head Is All You Need* In arXiv preprint arXiv:1911.02150, 2019

³⁷ J. Ainslie, J. Lee-Thorp, M. de Jong, Y. Zemlyanskiy, F. Lebrón, S. Sanghai, *GQA: Training Generalized Multi-Query Transformer Models from Multi-Head Checkpoints* In arXiv preprint arXiv:2305.13245, 2023

³⁸ W. Kwon, Z. Li, S. Zhuang, Y. Sheng, L. Zheng, C. H. Yu, J. E. Gonzalez, H. Zhang, I. Stoica, *Efficient Memory Management for Large Language Model Serving with PagedAttention* In arXiv preprint arXiv:2309.06180, 2023

每块容纳 2 个词元：逻辑顺序由块表恢复



物理缓存：按实际地址排列



一次具体寻址：读取 A 的“解释”（词元位置从 0 开始）




图 12.23 分页键值缓存的具体寻址。上方两条请求按逻辑顺序分块，并用块表保存物理块编号；下方为实际缓存布局。蓝色共同前缀只保存一份，A、B 的后续各占一块，无需保持物理连续。底部展开一次“位置 → 逻辑块 → 物理块及偏移”的查找。词元位置、逻辑块和表索引从 0 开始；物理块编号用 1 至 4 标识。框中的词仅标记其对应的 KV 内容，并非把原始文本当作键值向量。

12.4.2.9 不同扩展方向的比较

表 12.4 把模型变化与实现变化分开。若瓶颈是长序列位置对算术量, FlashAttention 与分页本身不会将其改成线性; 若瓶颈是解码缓存, 减少训练中的概率矩阵又不等于减少历史键值。门控、GQA、FlashAttention 和分页可以在兼容实现中组合, 因为它们分别作用于特征选择、键值组织、块内计算和缓存寻址。

方法	主要改善对象	改变标准稠密读取?	代价或限制
前缀等掩码	可用信息与任务约束	改变允许连接	需防止目标或跨段泄漏
门控注意力	输入相关的特征选择	增加乘性调制	增加参数; 不自动减少连接
稀疏注意力	位置对算术量	删除部分连接	范围受限; 依赖连接模式
线性注意力	聚合算术量及历史状态	改变核或近似 Softmax	依赖特征维 r 与核表达能力
低秩注意力	交互维度与算术量	压缩键值位置	近似误差; 因果性需另设计
FlashAttention	中间存储与显存访问	保持公式, 舍入可能不同	稠密算术仍为平方量级
MQA/GQA	KV 容量与解码带宽	跨头共享键值参数	改变自由度; 评分仍按查询头
PagedAttention	缓存分配与前缀共享	保持逻辑读取规则	块表管理; 真实键值仍占空间

表 12.4 注意力扩展的主要目标与取舍。比较以相同有效输入、隐藏宽度与预测条件为前提; 具体算术和存储量见各方法正文。降低算术量、减少访存、缩小 KV 缓存和减少内存碎片是不同指标, 实际速度还取决于实现与硬件。

12.4.3 前馈层的扩展

普通 FFN 先扩张特征, 再用统一激活筛选。若希望同一输入同时决定候选特征和通过程度, 可以设置两条投影分支。**门控线性单元** (gated linear unit, GLU) 用 Sigmoid 分支逐坐标调制另一分支; 应用于 Transformer 前馈层的一般形式为

$$\begin{aligned} \mathbf{B} &= \mathbf{H}\mathbf{W}_b + \mathbf{1}\mathbf{b}_b^\top, & \mathbf{D} &= \mathbf{H}\mathbf{W}_g + \mathbf{1}\mathbf{b}_g^\top, \\ \text{GFFN}(\mathbf{H}) &= (\mathbf{B} \odot \psi(\mathbf{D}))\mathbf{W}_o + \mathbf{1}\mathbf{b}_o^\top. \end{aligned} \quad (12.30)$$

两条输入投影均从 d 到 d_g , 输出投影从 d_g 恢复 d 。GLU 取 $\psi = \sigma$, **GEGLU** 取 GELU, **SwiGLU** 取 SiLU, 后两者分别用平滑激活调制特征。GELU 或 SiLU 可以输出负值且不限定在 $[0, 1]$, 因此这里“门控”表示乘性调制, 不完全等同于 LSTM 中的保留比例³⁹。

忽略偏置时, 普通 FFN 约有 $2dd_f$ 个参数, 门控 FFN 约有 $3dd_g$ 个参数。若保持这一参数预算, 可取 $d_g \approx 2d_f/3$; 比较同样中间宽度会同时改变参数和计算量。门控增加表达形式, 但也增加乘法分支和尺度选择, 不能仅凭名称判断泛化效果。

图 12.24 把“追”这一行的两条分支展开: 候选特征 $(2, -4)$ 与调制量 $(0.5, 2)$ 相乘, 得到 $(1, -8)$, 再经输出投影恢复 d 维。第二维被放大, 说明 GEGLU、SwiGLU 中的调制量不只是保留比例。这里用二维数值演示乘法, 实际中间宽度由 d_g 决定; 各位置仍独立处理, 没有新增跨位置读取。

³⁹ N. Shazeer, *GLU Variants Improve Transformer* In arXiv preprint arXiv:2002.05202, 2020




图 12.24 门控前馈层对“追”的一次逐位置计算。候选特征 $(2, -4)$ 与激活后的调制量 $(0.5, 2)$ 相乘为 $(1, -8)$ ，再经输出投影恢复隐藏宽度。数值是教学假设；大于 1 的调制量适用于 GEGLU 或 SwiGLU 的解释，GLU 的 Sigmoid 门则限制在 0 与 1 之间。猫、追、狗使用同一套参数分别计算，不发生跨位置读取。

12.4.4 混合专家：按输入选择计算路径

逐位置计算还可以按输入选择不同前馈网络。**混合专家** (mixture of experts, MoE) 设置多个专家和一个路由器，让不同位置使用不同专家组合。**专家** (expert) 是可训练的特征变换网络，**路由器** (router) 根据位置表示分配专家权重。设共有 e 个专家，单位置为 $\mathbf{h}$ ，路由概率为 $\mathbf{p} = \text{softmax}(\mathbf{W}_r^\top \mathbf{h})$ ， $\mathbf{W}_r \in \mathbb{R}^{d \times e}$ 。若只保留分数最大的 k 个专家集合 $T_k(\mathbf{h})$ ，可以计算

$$\text{MoE}(\mathbf{h}) = \sum_{a \in T_k(\mathbf{h})} \tilde{p}_a F_a(\mathbf{h}), \quad (12.31)$$

其中 $\tilde{p}_a$ 可取选中概率重新归一化后的权重，也可按具体方法保留原概率；训练性质依赖这一约定。总专家参数随 e 增长，一次位置计算主要激活 k 个专家，加上路由器及共享模块的开销，不能把总参数量直接当作每次计算量⁴⁰。

路由可能把大量位置分给少数专家，造成容量不足或计算负载不均。容量限制决定多余位置如何处理，负载均衡辅助目标约束专家使用分布；它们会改变训练目标或输出过程。Top- k 选择是离散的，常规反向传播只能在当前选择内对连续权重和专家求导，跨越选择边界的行为需要单独设计。若 $k = 1$ 并将唯一概率重新归一化为 1，仅从这条乘权路径无法训练

⁴⁰ N. Shazeer, A. Mirhoseini, K. Maziarz, A. Davis, Q. Le, G. Hinton, J. Dean, *Outrageously Large Neural Networks: The Sparsely-Gated Mixture-of-Experts Layer* In arXiv preprint arXiv:1701.06538, 2017

路由器，尤其需要保留可学习权重或其他训练信号。专家分工是学习结果，不能预先认定某个专家必然掌握某类知识；并行通信和调度代价也不能用稀疏激活参数量替代。

图 12.25 把路由决策与专家计算分开。对“迫”的同一个隐藏表示，假设路由概率为 $(0.1, 0.6, 0.1, 0.2)$ 。Top-2 选择专家 2 和 4，再除以所选概率之和 0.8，得到权重 0.75 和 0.25。两个专家都读取原隐藏表示 $\mathbf{h}$ ，而不是读取路由概率；假设它们分别输出 $(2, 0)^\top$ 和 $(0, 4)^\top$ ，加权相加后才得到 $(1.5, 1)^\top$ 。专家 1、3 在本次没有执行，参数仍属于模型。这里的概率与输出只供手算，不表示某个专家已被指定为某类词的专家。

专家通常替换部分块中的 FFN，注意力与残差仍可共享。不同位置可以选择不同专家，也可能选择相同专家；路由均衡关系到并行负载，并不等于专家应等权输出。




图 12.25 Top-2 混合专家的一次完整计算，概率与二维专家输出均为教学设定。上方路由器选出专家 2、4 并给出重新归一化的权重；下方实线传递隐藏表示及专家结果，虚线向乘法节点提供标量权重。专家输入始终是同一个 h ，加权发生在专家输出之后，最终 $0.75(2, 0)^T + 0.25(0, 4)^T = (1.5, 1)^T$ 。灰色专家 1、3 本次不计算；图省略容量限制、辅助训练目标及块外残差。

12.4.5 归一化的扩展

第12.2.4节已经给出逐位置 LayerNorm 及其残差块形式。扩展时仍需分别检查统计范围、是否减均值，以及归一化位于哪条路径：前两项决定消去哪些表示变化，后一项影响残差与梯度。通用归一化公式、批归一化（BatchNorm）、实例归一化（InstanceNorm）和组归一化（GroupNorm）的完整说明见第14.3节，统计轴对照见表 14.3。这里集中讨论 Transformer 中的因果限制、RMSNorm 与残差位置。

12.4.5.1 统计范围与因果限制

对批量激活 $\mathbf{X} \in \mathbb{R}^{b \times n \times d}$ ，三个轴分别是样本、位置和特征。式(12.9)固定样本和位置，只沿 d 个特征统计；不同位置不交换均值与方差，训练与预测均使用当前行的统计量，不需要运行均值。LayerNorm 的“层”并不表示把整批或整段的元素放在一起。

完整已知的图像或离线编码可以使用跨空间、跨位置统计；因果解码则要求位置 i 的统计量不能包含 $j > i$ 的激活。只要均值或方差读取了未来，即使注意力有三角掩码也会泄漏。把 BatchNorm、InstanceNorm 或 GroupNorm 设为跨整段统计时，必须另行设计满足因果条件的统计方案，不能直接替换逐位置归一化。训练用全段统计、预测用前缀统计还会引入额外不一致；填充也不能作为有效观测参与统计。

12.4.5.2 不减均值的 RMSNorm

中心化不是调整尺度的唯一方式。**均方根归一化**（root mean square normalization, RMSNorm）不减去均值，而按坐标均方根缩放：

$$\text{RMSNorm}(\mathbf{x}) = \gamma \odot \frac{\mathbf{x}}{\sqrt{d^{-1} \sum_{k=1}^d x_k^2 + \varepsilon}}。 \quad (12.32)$$

这里采用常见的无平移形式。它与逐位置 LayerNorm 均只读取当前行，但少了均值计算和相减。给各坐标加同一常数时，LayerNorm 的中心化结果不变，RMSNorm 的结果一般会变；忽略 ε 时，二者都消去正比例整体缩放，实际耗时仍由实现与形状决定⁴¹。

逐位置统计满足这一局部因果条件，却不保证归一化保留了任务需要的均值或幅度。只调整整行长度的尺度归一化（ScaleNorm）见第14.3.1.3节；直接重参数化权重、而非统计激活的权重归一化（WeightNorm）见第14.3.2.1节。它们改变的对象不同，不能仅凭名称作为 LayerNorm 的等价替代。

⁴¹ B. Zhang, R. Sennrich, *Root Mean Square Layer Normalization* In arXiv preprint arXiv:1910.07467, 2019

12.4.5.3 归一化位置：Pre-LN、Post-LN 与组合

归一化的位置改变残差路径。Post-LN 子层 $\mathbf{y} = \text{LN}(\mathbf{x} + F(\mathbf{x}))$ 的雅可比为 $\mathbf{J}_{\text{LN}}(\mathbf{I} + \mathbf{J}_F)$ ，直接路径也要经过 LN；Pre-LN 的雅可比为 $\mathbf{I} + \mathbf{J}_F \mathbf{J}_{\text{LN}}$ ，恒等路径绕过 LN。Xiong 等在特定初始化与模型分析下比较了两者的梯度尺度，并解释了原始 Post-LN 训练中学习率预热的重要性；Pre-LN 改善该问题的条件不能扩写为所有深度和优化设置都更优⁴²。

也可以在子层前和输出端分别归一化，控制输入与支路输出的尺度。例如，把子层的归一化输入记为 $\mathbf{u}$ ，计算

$$\begin{aligned}\mathbf{u} &= \text{Norm}_{\text{in}}(\mathbf{x}), \\ \mathbf{y} &= \mathbf{x} + \text{Norm}_{\text{out}}(F(\mathbf{u})).\end{aligned}\tag{12.33}$$

它与 $\text{Norm}(\mathbf{x} + F(\mathbf{x}))$ 不同，恒等路径是否经过归一化仍需按真实公式判断。RMSNorm 可放在前或后，LayerNorm 也可采用不同位置；“采用何种统计量”与“放在何处”不应混作一种分类。归一化分母、可学习缩放、残差累积和末端读出共同影响信号，任何单一局部机制都不足以保证整网梯度稳定。

12.4.6 深层连接的扩展

直接堆叠残差块仍可能积累过大的更新或使深层分支难以学习。一般子层可写为 $\mathbf{h}^{(l)} = b_l \mathbf{h}^{(l-1)} + a_l F_l(\mathbf{h}^{(l-1)})$ ，其中 a_l 控制新增变换， b_l 控制原表示的传递。固定缩放可以与深度相关，可学习缩放则让训练决定每条分支的影响；它们都要与归一化和初始化共同考虑。

ReZero 给每条残差支路设置一个初始化为 0 的可学习标量 a_l ，使用 $\mathbf{h}^{(l)} = \mathbf{h}^{(l-1)} + a_l F_l(\mathbf{h}^{(l-1)})$ 。在该残差堆叠不含其他破坏恒等路径的操作时，初始映射和局部雅可比都是恒等。初始步骤中支路内部参数梯度受 $a_l = 0$ 抑制，但门参数有梯度 $\partial \ell / \partial a_l = \langle \mathbf{g}^{(l)}, F_l(\mathbf{h}^{(l-1)}) \rangle$ ，门偏离 0 后支路开始收到监督。它调整新增层何时参与计算，不等于将支路内部全部权重重置⁴³。


门也可以是逐特征向量或输入相关函数，形成不同粒度的残差控制。向量门增加参数，自适应门增加计算和新的梯度路径；Sigmoid 门如果希望初始接近关闭，偏置与饱和程度就需配合。更广的跨层连接还可把早期层的表示相加或拼接到深层，相加要求维度匹配，拼接会增加宽度并通常需要投影。这些改变影响表示复用、保存激活的数量和梯度路径，不能只依据最短路径长度评价整网优化。

图 12.26 对照归一化位置与支路缩放。把 Norm 移到子层之前，保留的是绕过 Norm 的恒等路径；在支路加入标量，控制的是新增变换的强度。这两个选择可以同时使用。

⁴² R. Xiong, Y. Yang, D. He, K. Zheng, S. Zheng, C. Xing, H. Zhang, Y. Lan, L. Wang, T.-Y. Liu, *On Layer Normalization in the Transformer Architecture* In arXiv preprint arXiv:2002.04745, 2020


⁴³ T. Bachlechner, B. P. Majumder, H. H. Mao, G. W. Cottrell, J. McAuley, *ReZero Is All You Need: Fast Convergence at Large Depth* In arXiv preprint arXiv:2003.04887, 2020

Post-LN




$$y = \text{LN}(x + F(x))$$

Pre-LN



$$y = x + F(\text{LN}(x))$$

缩放残差



$$y = x + a_l F_l(x), \quad a_l = 0 \Rightarrow y = x$$

图 12.26 把恒等路径放在同一水平线上比较三种残差组织。Post-LN 的原输入在相加后仍通过 LN；Pre-LN 只有下方变换支路经过 LN，恒等路径可以直接到达输出。第三行以 a_l 缩放新增变换， $a_l = 0$ 时该子层输出等于输入；ReZero 采用这一初值，图中省略可选归一化。各行上方路径传递原表示，下方路径计算新增变换，+ 为逐元素相加。

12.4.7 混合网络结构

注意力擅长显式读取位置，但没有默认的局部窗口或固定容量历史状态。若输入具有稳定局部模式，可以用卷积前端提取特征、降低分辨率，再把特征位置送入 Transformer；窗口内部的卷积共享与注意力的内容相关读取承担不同职责。下采样减少序列长度，会明显改变后续平方位置对成本，也可能丢失细粒度信息，输出任务需要保留或恢复相应分辨率。

模块也可以交替堆叠。例如用状态空间模块压缩历史，用注意力层在保留位置之间进行显式检索；或者先用循环网络处理陆续到达的观测，再在给定窗口内交换信息。串联改变后一个模块接收到的表示，注意力无法恢复前端已经丢掉的细节。并行分支则可以分别形成局部与全局表示，再相加或拼接，维度、位置对齐和因果规则仍需一致。

混合结构的成本不能只取其中最便宜的模块：只要保留稠密注意力层，整段处理仍有平方量级的位置对计算；生成时，该层需保存随历史长度线性增长的 KV 缓存。训练中间存储另取决于实现，FlashAttention 不必保存完整的平方规模注意力矩阵；固定状态模块的存储优势也只覆盖该模块。前端、交替与并行是不同组织方式，应围绕任务需要的局部模式、精确历史读取、延迟和计算预算选择。

图 12.27 比较前端、交替与并行三种组织。它们分别改变输入粒度、层间分工与融合方式，使用哪一种都需要保持位置对应和信息可见规则。




图 12.27 三种混合结构改变的是不同环节。左图以窗口 2、步长 2 的卷积前端将 6 个输入位置变成 3 个特征位置，再交给注意力；中图对猫、追、狗递推状态，并将各位置输出交给注意力层，随后继续交替；右图对同一序列并行计算局部卷积和注意力， C 表示按特征维拼接，再经投影融合。并行分支采用保持长度的位置对齐设置，所有分支还需满足任务的因果约束。

12.5 理论分析

短的信息路径、可微的运算和共享参数说明了计算如何构成，还没有回答训练能否达到目标、所得规则能否用于新样本。这里沿用机器学习理论部分的风险与优化框架，将注意力、归一化、长度和结构约束放入相应条件。结论的对象需要分清：梯度的局部尺度、经验目标的下降与未见输入上的风险分别需要不同依据。

12.5.1 收敛性

Softmax 雅可比 $\mathbf{J} = \text{diag}(\mathbf{a}) - \mathbf{a}\mathbf{a}^\top$ 的谱范数不超过 $1/2$ 。可由每行绝对值之和 $2a_j(1 - a_j) \leq 1/2$ 以及对称性得到这一界。它控制的是对得分的局部敏感度；当权重接近单点时，雅可比还可能趋近零。因此，Softmax 本身不会无限放大得分梯度，却可能使某些评分参数难以收到足够梯度。

注意力对输入的敏感度还包含查询、键和值的变化。单头记 $\mathbf{Z} = \mathbf{A}\mathbf{V}$ ，固定掩码时微分为

$$\begin{aligned} d\mathbf{Z} &= (d\mathbf{A})\mathbf{V} + \mathbf{A}d\mathbf{V}, \\ d\mathbf{S} &= \frac{(d\mathbf{Q})\mathbf{K}^\top + \mathbf{Q}(d\mathbf{K})^\top}{\sqrt{d_k}}. \end{aligned} \quad (12.34)$$

结合逐行 Softmax 界和矩阵范数不等式，可得局部估计

$$\begin{aligned} \|d\mathbf{Z}\|_F &\leq \frac{\|\mathbf{V}\|_2}{2\sqrt{d_k}} (\|\mathbf{K}\|_2 \|d\mathbf{Q}\|_F + \|\mathbf{Q}\|_2 \|d\mathbf{K}\|_F) \\ &\quad + \|\mathbf{A}\|_2 \|d\mathbf{V}\|_F, \end{aligned} \quad (12.35)$$

其中矩阵 $\|\cdot\|_2$ 为谱范数， $\|\cdot\|_F$ 为 Frobenius 范数。输入到投影的敏感度还乘以各 $\mathbf{W}$ 的范数。行权重和为 1 控制了单个输出是值的凸组合，却不保证 $\|\mathbf{A}\|_2 \leq 1$ ：所有查询都读取同一个值时，该值的影响会在多行重复，谱范数可以达到 $\sqrt{n}$ 。用最大行向量范数分析可能得到另一种长度依赖，不能跨范数直接替换结论。

归一化的分母含 ε ，其局部导数还受可学习缩放和行内方差影响。残差堆叠则包含多个 $\mathbf{I} + \mathbf{J}_l$ 的乘积，即使直接路径存在，其他分支仍可能累积放大、衰减或抵消。Pre-LN、残差缩放和门控改变这一乘积，但不自动保证全部奇异值接近 1。深度增加、输入长度变长或投影尺度改变，都可能使原来合理的学习率不再适合。

把这些局部因素转为优化结论，需要明确经验目标和轨迹条件。令 $J(\theta)$ 为确定性的全批量经验目标，假定它有下界 $J_{\inf}$ ，并在包含迭代点及更新线段的区域内具有 β -Lipschitz 梯度。对学习率 $0 < \eta \leq 1/\beta$ 的梯度下降，

下降引理给出

$$\begin{aligned} J(\boldsymbol{\theta}^{(t+1)}) &\leq J(\boldsymbol{\theta}^{(t)}) - \frac{\eta}{2} \|\nabla J(\boldsymbol{\theta}^{(t)})\|_2^2, \\ \min_{0 \leq t < T} \|\nabla J(\boldsymbol{\theta}^{(t)})\|_2^2 &\leq \frac{2(J(\boldsymbol{\theta}^{(0)}) - J_{\inf})}{\eta T}. \end{aligned} \quad (12.36)$$

第二行来自第一行求和。它保证迭代中出现小梯度点，不保证参数序列收敛到同一个点，更不保证全局最优或训练误差很小。对有界参数、固定最大长度、光滑激活和正归一化分母的网络，可以在适当紧区域控制光滑常数；ReLU 拐点、离散专家路由、随机 Dropout 或缓存近似不能未经说明直接套用这个光滑全批量结论。

要进一步保证目标差距下降，例如需要沿轨迹满足 $\|\nabla J\|_2^2 \geq 2\mu(J - J_*)$ 的 Polyak-Łojasiewicz 条件，其中 $\mu > 0$ 且 J_* 为所比较的最优值，才可由上式得到几何下降。真实 Transformer 并不普遍满足该条件。第二卷“基础、理论和可信性”的“深度学习的可学习性”章“固定 NTK 下的训练收敛”定理给出的固定核附近分析也依赖宽度、初始化和核特征值等条件，不能直接覆盖有限宽度中的任意特征学习。

随机梯度的结论另需无偏性、方差和步长条件；Adam 类自适应更新也有不同的假设。实践中的损失没有尖峰，只说明观察到的训练行为平稳；收敛到驻点描述优化梯度；较小训练误差还要求模型与数据相容并且算法找到相应参数。这三种说法应在各自条件下使用。

12.5.2 泛化能力

以序列分类为例，一个样本 $z = (x, y)$ 包含完整输入序列和标签。若训练集 $S = \{z_1, \dots, z_N\}$ 由同一分布独立抽取，期望风险为 $R(f) = \mathbb{E}\ell(f(x), y)$ ，经验风险为 $\hat{R}_S(f) = N^{-1} \sum_{j=1}^N \ell(f(x_j), y_j)$ 。这里 N 是独立序列数， n 是单序列长度，不能混用。序列内部位置相关，不会仅因为有 Nn 个词元就自动变成 Nn 个独立样本。

在抽样前固定模型族 $\mathcal{F}$ 、允许长度和损失范围，令 $\mathcal{G} = \{z \mapsto \ell(f(x), y) : f \in \mathcal{F}\}$ ，若损失取值于 $[0, 1]$ 且满足可测性条件，第二卷“基础、理论和可信性”的“二分类学习的可学习性”章“Rademacher 复杂度给出的期望风险上界”定理给出以至少 $1 - \delta$ 的概率同时成立的界

$$R(f) \leq \hat{R}_S(f) + 2\hat{\mathfrak{R}}_S(\mathcal{G}) + 3\sqrt{\frac{\log(2/\delta)}{2N}}. \quad (12.37)$$

这不是 Transformer 独有的界；该网络的输入范围、投影范数、层数、头数和读出方式进入损失函数族的复杂度。交叉熵一般无界，不能不加条件套用 $[0, 1]$ 版本，可以在概率下界成立时控制损失，或另用适合无界损失的理论。上界宽松时，它只能提供条件分析，不能作为测试错误率的数值

预测。

12.5.2.1 输入与数据

序列长度同时改变可见证据、计算图规模和数据分布。若每行输入范数不超过 b ，整个矩阵 Frobenius 范数仍可能达到 $\sqrt{n}b$ ；位置表示的尺度也要计入。第12.35式说明，谱范数分析可能把这些长度因素带入敏感度和复杂度。另一方面，长度变长也可能提供更多有用信息，所以不能仅由某个界随 n 增大就断言任务风险必然变差。

样本量需要与依赖结构匹配。独立文档可以作为样本，而同一连续记录中的重叠窗口、同一用户的多段文本或同一图像的多个块可能相关；数据划分和风险定义应反映这些关系。输入尺度过大、词元频率变化、噪声位置增加或训练与测试长度分布不同，都会改变预测器实际遇到的条件。注意力能够连接两个位置，也不能弥补训练中缺少相关任务模式。

12.5.2.2 参数与学习过程

查询键范数控制得分尺度，值与输出投影范数控制读取结果，前馈层和归一化缩放影响后续敏感度。参数总数给出一个粗略的容量尺度，但共享投影在所有位置使用，不能简单按 n 乘上参数量；计算图随长度增长也并未因此从分析中消失。控制参数范数、分类间隔或适合任务的有效自由度，可以提供比总参数数目更有条件的描述。

训练算法还决定实际选择了哪个参数。正则化、停止时间和步长会改变样本替换对输出的影响；若能证明一致稳定性系数为 ϵ_{stab} ，第二卷“基础、理论和可信性”的“一般学习的可学习性”章“均匀稳定性与期望风险”定理将它联系到期望泛化间隙。存在稳定性工具不意味着 Transformer 训练天然稳定：还需控制注意力、归一化和优化轨迹的敏感度。模型选择若多次查看验证集，也应将选择过程纳入评估，而不能只分析最后一组固定参数。

12.5.2.3 网络结构与外推边界

深度提供多轮交互和变换，宽度和头数改变可保留的特征、评分及聚合形式；固定总宽度时，更多头同时减少每头宽度。稀疏连接减少允许的交互，门控和专家路由增加条件计算自由度，位置编码引入顺序与距离规律。这些设计可能与数据结构相匹配，也可能排除任务需要的函数。限制函数族可以降低某些复杂度，却可能提高逼近误差，需要同时考虑。

同分布泛化 (in-distribution generalization) 要求新样本来自训练所对应的分布；**长度外推** (length extrapolation) 要求在训练未覆盖的更长输入上复用规则；**分布外泛化** (out-of-distribution generalization) 则改变输

入或任务条件。一个模型在同长度新文本上低风险，不能推出它会在更长文本中执行相同算法，也不能推出领域变化后的可靠性。

固定正弦、ALiBi 和 RoPE 提供可用于新位置的计算规律，长度外推还涉及内容分布、距离分布、聚合稀释、层数是否足够及读出规则。因果生成只依赖此前词元，也不保证模型能维持任意长的语义一致性。机器学习理论部分的第二卷“基础、理论和可信性”的“深度学习的可学习性”章“学习设定扩展的理论边界”节说明，跨任务学习与长度外推需要重新明确任务、目标分布和预测过程；本章的结构比较提供这些分析所需的具体计算对象。

12.6 常见应用

应用中的完整模型需要把输入单位、可见信息、输出含义和监督位置对应起来。以下沿用前文的网络块与损失，只展开从样本到预测的路径；数据构建、任务专用结构与评价方法由应用卷细化。

12.6.1 文本分类与序列标注

评论情感分类的样本是文本和类别。分词后查表形成嵌入，加位置表示，使用双向编码器得到上下文表示，再采用 CLS 或掩码池化读出，经 Softmax 分类。以“这部电影并不精彩”为例，编码器给“精彩”的表示可以读取否定上下文，整段分类头据此输出类别。这个任务动机不代表某个注意力头必然学习了否定规则，仍需用独立样本检验预测。

训练对评论计算交叉熵，嵌入、编码器和分类头共同更新；如果先使用已有模型，再训练任务头或微调部分层，需要明确哪些参数更新。推理使用同一分词与有效位置规则，输出整段概率。截断长评论会删除可能有用的证据，应在输入策略和测试条件中保持一致。

实体标注则将每个有效位置表示送入共享分类头，计算对应标签损失。若一个词被拆成多个子词，标签需选择监督首个子词、监督所有子词，或先聚合为词表示，推理时也使用同一规则。逐位置 Softmax 可以预测标签概率，却不显式保证跨位置标签组合合法；需要结构约束时可增加相应输出模型。离线标注读取整段，流式标注使用因果或有限延迟范围，这个约束比“采用编码器还是解码器”的名称更直接。

12.6.2 序列转换与生成

机器翻译训练使用源句 x 和包含 EOS 的目标 y 。源嵌入和编码器产生 H_s ，目标输入右移，因果自注意力读取真实目标前缀，交叉注意力读取有效源位置，以式(12.12)更新两侧嵌入、所有网络块和词表输出层。源目标不要求逐词对齐，也无需给注意力另加一个必须满足的对齐标签。

推理时源端只编码一次，各目标层还可预先缓存该层交叉注意力的源键值。目标从 BOS 开始，经过各层生成词表分布，选择词元后追加该层自注意力缓存，再继续，遇到 EOS 或长度上限停止。不同层的投影参数不同，因此源交叉键值与目标自注意力键值都按层保存。束搜索存在多个候选前缀时，可以共享未变的缓存内容，分叉后的修改则需各自维护或按写入时复制处理。

文本续写不需要独立源编码器。已给定提示先做预填充，末位置输出预测提示后的第一个词元；把选出的词元作为新输入，在各层追加缓存，得到下一词元分布。续写中采用完整已生成前缀，是模型定义的一部分，不能将训练时真实前缀与生成时自身前缀的差异忽略。选择温度、采样或搜索策略会影响输出，评价需使用实际采用的生成过程。

12.6.3 图像分类

图像没有天然的一维词元序列，但可以把小块作为输入单位。**视觉 Transformer** (Vision Transformer, ViT) 将图像分成块，分别嵌入后进行位置间注意力，再读出图像类别⁴⁴。

设图像高宽为 H, W 、通道数为 c ，块边长为 p ，并暂设 H, W 可被 p 整除，则块数为 $n = HW/p^2$ ，每块展平向量 $\mathbf{x}_i \in \mathbb{R}^{p^2c}$ 。投影后的输入为

$$\mathbf{h}_i^{(0)} = \mathbf{W}_p^\top \mathbf{x}_i + \mathbf{b}_p + \mathbf{p}_i, \quad \mathbf{W}_p \in \mathbb{R}^{p^2c \times d}. \quad (12.38)$$

位置索引按固定网格顺序排列，位置表示须保留块与空间位置的对应。加入专用分类位置后，共有 $n + 1$ 行表示，经编码器、末端归一化和分类头产生概率，以图像标签交叉熵训练。图 12.28 把图像块、序列表示与分类输出连接起来。

⁴⁴ A. Dosovitskiy, L. Beyer, A. Kolesnikov, D. Weissenborn, X. Zhai, T. Unterthiner, M. Dehghani, M. Minderer, G. Heigold, S. Gelly, J. Uszkoreit, N. Houlsby, *An Image Is Worth 16x16 Words: Transformers for Image Recognition at Scale* In arXiv preprint arXiv:2010.11929, 2020




图 12.28 ViT 将图像组织为序列的过程。示意图像有 4×4 个像素，切成四个 2×2 图像块，按从左到右、从上到下的顺序编号；每块展平后通过同一线性投影形成 e_i 。在开头加入可学习 CLS 表示，为五行分别加入位置向量，再送入双向编码器。分类头只读取末层 CLS 行，其他图像块通过注意力参与其形成。图中像素色块仅为结构示意，并非真实识别样本。

图像块之间可直接交互，但块内部结构在原始 ViT 中经一次线性投影进入表示，没有逐层卷积的局部共享假设。较小的 p 保留更细的位置划分，同时使 n 增长；固定图像尺寸时，稠密注意力位置对数与 p^{-4} 同阶，前馈层的块数成本则与 p^{-2} 同阶。改变图像分辨率会改变网格和位置数量，可学习位置表常需按空间网格插值；插值只是提供新输入表示，分类质量仍应检验。数据量、预训练、局部模块和增强会影响实际效果，不能从架构名称直接推出比卷积网络更适合任何图像数据。

12.7 本章小结

Transformer 把序列中的位置依赖转为显式读取：内容表示给出查询、键和值，位置表示和掩码约束怎样匹配以及哪些位置可见，多头注意力形成不同聚合，逐位置前馈网络再组合这些特征。残差和归一化让这套计算能够层层堆叠。与循环注意力相比，它不再要求已知位置沿时间逐个更新；输出尚未产生时，自回归条件仍要求逐步生成，缓存只是复用已经完成的计算。

结构与资源的选择需要同时看任务。双向读取适合完整输入理解，因果读取满足在线与生成条件，交叉注意力将源目标表示分开。位置扩展提供不同距离规律，门控和专家改变特征选择；稀疏、线性和低秩路线改变读取结构或公式，FlashAttention 保留稠密计算而减少中间访存，MQA/GQA 缩小键值组数，PagedAttention 改善缓存分配与共享。减少哪一种开销、改变哪一种表示自由度，决定了这些方法的组合与取舍。

梯度推导说明读取路径和评分路径怎样共同接收监督，却没有取消优化与泛化的条件。得分尺度、归一化分母、残差深度和长度共同影响学习，独立样本数、参数约束、数据分布和评价目标共同约束风险结论。由此可以回答章首的问题：直接位置交互使已知输入的计算更易并行，但可靠预测还取决于可见范围是否正确、任务信息是否保留，以及学习结果是否在实际使用条件下得到检验。

脉冲神经网络

前面的网络通常在一次计算中传递实数向量。即使输入是序列，每个时间步也会产生一组连续值表示。如果传感器只在信号变化时报告事件，或者计算设备通过离散脉冲通信，网络还能怎样保留强度、顺序和历史信息？此时，传递了多少次信号、信号何时到达，以及两次信号之间的状态变化，都可能参与计算。

第7章介绍了生物神经元通过发放事件通信，第10章的液态状态机则展示了固定脉冲储备池与可训练读出的分工。这里进一步追问：怎样把这种通信变为完整的可学习模型？它与连续值网络的差异发生在编码、状态还是连接上，什么任务又值得承担额外的时间模拟与训练成本？

脉冲是通信形式，膜电位是内部状态，两者需要分别建模。只有建立这一区别，才能理解网络为何可以在两次输入之间保留信息，也才能判断少量脉冲是否真的减少了整体计算。以下使用离散时间模型展开可复核的计算，并在需要时说明它与连续时间动态的关系。

13.1 脉冲神经网络概述

13.1.1 提出动机与核心思想

生物细胞的膜电位连续变化，远距离通信却主要通过短暂的动作电位完成。若只用一个实数激活概括活动，就会省略单次发放的时刻、相邻事件的间隔，以及未达到阈值时的内部积累。研究神经计算时，这些信息本身就是要解释的对象；处理变化驱动的传感器时，它们又是输入已经提供的结构。

脉冲神经网络（spiking neural network, SNN）以离散发放事件在单元之间传递信息，单元内部保存随时间演化的状态。一个脉冲通常只报告某单元在某时刻发放；信号的强度和时序关系由发放次数、发生时刻及发放单元共同承载。接收单元积累这些输入，旧输入逐渐衰减，状态越过阈值时再产生新事件。它既是一种信息编码方式，也是一类带阈值、复位与时间动态的网络模型。

提出这类模型有两条相互联系的动机。一条来自神经科学：用可计算的动态解释细胞如何对输入作出响应，以及局部连接怎样形成行为。另一条来自工程：若变化稀疏，能否只在事件发生时传递和处理必要信息，减少持续感知中的通信与计算？第二条动机要求传感器、编码、模型和执行设备共同配合；仅把实数激活替换成0与1，不能自动得到低能耗系统。

SNN也不要求完全复现生物细胞。模型可以只保留积累、泄漏、阈值和复位，权重可以通过任务损失学习，输出还可以使用连续值读出。这使生物启发与人工任务连接起来，但同时需要分别判断生物解释是否合理、任务预测是否有效，以及实现是否利用了事件稀疏性。

13.1.2 从神经元建模到神经形态计算

脉冲网络不是在某一年由一篇论文完整提出的。早期神经元模型、时序编码研究和硬件设计逐步汇合，才形成今天的研究方向。1907年Lapicque的积分发放思想将输入电流的积累与阈值发放联系起来，是早期简化动态模型的一条路线¹。

1952年Hodgkin与Huxley从离子电流出发建立动作电位的定量模型。与积分发放模型相比，它解释波形产生机制，说明神经元模型可以在不同生物细节层次上工作：简化模型便于组织较大网络，细致模型则服务于膜电流和发放机制研究²。

1990年，Mead系统讨论**神经形态电子系统**（neuromorphic electronic systems），即借鉴神经系统组织与动态来设计电子计算系统。它关注的不仅是某个神经元方程，还包括局部连接、并行动态和物理实现；神经形态计算的范围因此比某一种SNN模型更广³。

1997年，Maass以“第三代神经网络模型”讨论脉冲单元的计算能力，把发放时间明确纳入计算。这个代际说法突出阈值单元、连续激活和脉冲时序之间的差异，不表示后出现的模型会在所有任务上取代前面的模型。其表达能力结论依赖编码和单元模型，不能直接换算成真实设备上的精度或能耗优势⁴。

脉冲储备池进一步展示了利用复杂动态而不训练全部循环连接的路线。2002年的液态状态机让输入扰动一个固定循环系统，再训练读出使用其动态状态；第10.3.2节已给出这种分工。局部可塑性则从突触两端活动出发调整连接，为无需完整反向传播的学习提供另一条路径。两者回答的都是“怎样利用时序”，但并不等于解决了任意监督任务的全网信用分配。

13.1.3 深层网络与训练方法的发展

当目标从解释局部动态转为学习多层分类器，离散阈值成为主要困难。2002年，Bohte等提出SpikeProp，根据发放时刻与目标时刻之间的误差进行反

¹ W. Gerstner, W. M. Kistler, R. Naud, L. Paninski, *Neuronal Dynamics: From Single Neurons to Networks and Models of Cognition*, Cambridge University Press, 2014, 1st ed.

² A. L. Hodgkin, A. F. Huxley, *A Quantitative Description of Membrane Current and Its Application to Conduction and Excitation in Nerve* In The Journal of Physiology, 1952, vol. 117, no. 4, pp. 500–544

³ C. Mead, *Neuromorphic Electronic Systems* In Proceedings of the IEEE, 1990, vol. 78, no. 10, pp. 1629–1636

⁴ W. Maass, *Networks of Spiking Neurons: The Third Generation of Neural Network Models* In Neural Networks, 1997, vol. 10, no. 9, pp. 1659–1671

向计算；它在特定发放和模型条件下处理时间求导，并不是直接对任意二值脉冲使用普通反向传播⁵。

后来的两条路线让深度学习经验更容易进入 SNN。一条先训练连续值网络，再校准权重和阈值，使脉冲统计近似原激活；另一条在前向保留离散发放，在反向指定替代导数，直接优化任务损失。第13.3节会分别说明转换误差和替代梯度的近似性质。2019 年的替代梯度综述系统整理了后一条路线，其意义是提供可用的训练信号，而不是消除阈值的不连续性⁶。

可训练性改善后，研究开始扩展深度与信息交互方式。2021 年的 SEW-ResNet 研究怎样在脉冲残差路径中保持合适的传播；2022 年发布、2023 年发表于 ICLR 的 Spikformer 则将脉冲形式的查询、键和值用于注意力计算。残差与注意力为 SNN 提供新的组织方式，具体设计仍需检查内部是否保留连续运算、怎样使用时间步，以及哪些操作能映射到目标硬件⁷。

Spikformer 说明 SNN 与 Transformer 不是互斥类别：前者规定事件编码和神经元动态，后者强调信息读取与层间组织。将两者结合，不等于普通 Transformer 的每个模块都能直接改成脉冲，也不意味着静态图像上的多步推理天然具有事件传感器的稀疏性⁸。

13.1.4 与连续值神经网络的比较

两类网络都可以有前馈、卷积、循环或注意力连接，区别主要在单元输出与时间动态。普通前馈单元一次产生实数激活；脉冲单元先更新内部状态，再决定是否发放。第10.3.2节的漏积分发放（leaky integrate-and-fire, LIF）单元即使没有循环边，也能用膜电位保存过去输入的影响，而普通逐帧前馈网络通常没有跨帧状态。与 RNN 比较时，这个差异要收窄：RNN 本身也保存状态，SNN 额外明确了发放、复位与事件通信。

脉冲也不等同于二值神经网络的低比特激活。二值单元可以在每层计算中输出一个比特，未必具有持续膜电位或有意义的发放时刻；SNN 中的 0 则通常表示这一时间区间没有事件，过去输入仍可能保留在状态中。表 13.1 按这些机制比较，避免用单个标签概括整套系统。

比较维度	连续值网络	脉冲神经网络
通信变量	实数激活或向量	发放事件；数量与时刻共同承载信息
单元内部状态	前馈单元通常无跨输入状态；RNN 有状态	膜电位、突触响应及可选适应状态
时间关系	由递推、位置或时间特征表达	由事件时刻、积累、泄漏与延迟表达
求导困难	常见激活可微或分段可微	阈值发放不连续，需特别处理
训练路线	任务梯度及其他学习方法	局部规则、时间求导、替代梯度或网络转换
执行成本	取决于算子、稀疏性与设备	还取决于观察窗口、事件访问和状态更新
输出形式	分类分数、概率或连续量	计数、发放时间或连续状态读出

表 13.1 以常见人工模型比较两类网络。连续值网络也能使用稀疏计算、动态状态和局部学习；SNN 也可能在通用设备上按固定时间步进行稠密计算。表中列出机制差异，不据此给出普遍精度或能耗排序。

⁵ S. M. Bohte, J. N. Kok, H. la Poutre, *Error-backpropagation in Temporally Encoded Networks of Spiking Neurons* In Neurocomputing, 2002, vol. 48, no. 1–4, pp. 17–37

⁶ E. O. Neftci, H. Mostafa, F. Zenke, *Surrogate Gradient Learning in Spiking Neural Networks: Bringing the Power of Gradient-Based Optimization to Spiking Neural Networks* In IEEE Signal Processing Magazine, 2019, vol. 36, no. 6, pp. 51–63

⁷ W. Fang, Z. Yu, Y. Chen, T. Huang, T. Masquelier, Y. Tian, *Deep Residual Learning in Spiking Neural Networks* In Advances in Neural Information Processing Systems 34, 2021, pp. 21056–21069

⁸ Z. Zhou, Y. Zhu, C. He, Y. Wang, S. Yan, Y. Tian, L. Yuan, *Spikformer: When Spiking Neural Network Meets Transformer* In International Conference on Learning Representations, 2023

13.1.5 应用现状与发展方向

事件视觉、稀疏声音或触觉感知、持续监测与机器人响应，是SNN值得研究的场景：输入随时间到达，变化可能稀疏，决策又关心响应延迟。2017年Amir等将事件相机、脉冲识别网络与TrueNorth处理器用于实时手势识别，给出了传感器到设备执行的完整研究系统。这比只在静态图像上报告分类精度更接近事件计算的应用动机，但仍应按其任务、设备和测试条件理解结果⁹。

硬件的发展提供了更灵活的实验平台。Loihi面向事件通信、神经元状态和片上学习；Loihi 2进一步支持可编程神经元动态。Intel于2024年公布并部署到Sandia的Hala Point，以Loihi 2构成大规模神经形态研究系统。这里“部署”指研究设施中的系统交付，不能据此推断SNN已成为通用生产工作负载的默认选择¹⁰。

应用前景取决于完整链路。若输入本来是密集静态图像，需要编码并模拟许多时间步，事件数量和等待时间可能抵消部分收益；若输入是稀疏事件流，输出还需在较短窗口内可靠形成，噪声、低发放量和阈值校准就更关键。把分类结果、能耗估计和实际设备测量分开报告，才能知道改进来自模型、编码还是实现。

已有发展显示两条仍在推进的路线：一条扩大模型的可训练深度、注意力组织和任务范围，另一条围绕稀疏传感器与专用设备共同设计编码、动态和执行方式。由这些研究结果可以提出的判断是，SNN已经具备训练深层任务模型与构造完整实验系统的能力；更广泛的使用仍需要可靠的软件工具、相同条件下的基线比较，以及对状态存储、数据适配和训练成本的控制。这些约束也是后面结构、学习和理论分析需要回答的问题。

13.2 网络结构

脉冲网络由输入编码、带状态的神经元、突触连接和读出组成。连接决定事件送到哪里，神经元动态决定事件到达后留下什么状态、何时产生下一次发放。以下先明确输入事件，再拆开单元内部的计算，随后组合为前馈和循环网络。

13.2.1 频率编码与时间编码

假设一个传感器在一段时间内观察到某种强度。连续值网络可以直接接收这个数，脉冲网络则需要约定如何把它写进事件序列。对第*i*个输入通道，记发放时刻为 $t_{i,k}$ 。连续时间的脉冲列可以形式化为

$$s_i(t) = \sum_k \delta(t - t_{i,k}), \quad (13.1)$$

⁹ A. Amir, B. Taba, D. Berg, T. Melano, J. McKinstry, C. Di Nolfo, T. Nayak, A. Andreopoulos, G. Garreau, M. Mendoza, J. Kusnitz, M. DeBole, S. Esser, T. Delbruck, M. Flickner, D. Modha, *A Low Power, Fully Event-Based Gesture Recognition System* In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2017, pp. 7243–7252

¹⁰ Intel, *Intel Builds World's Largest Neuromorphic System to Enable More Sustainable AI*, Apr. 17, 2024, URL: <https://www.intel.com/content/www/us/en/newsroom/news/intel-builds-worlds-largest-neuromorphic-system.html> (visited on 10/04/2026)

其中 δ 为 Dirac 脉冲，其意义通过积分给出：对一个只包含某次发放的时间区间积分，得到 1。这个表示省略了动作电位的波形，只记录事件时刻。计算机模拟常将时间分为宽度 Δt 的 K 个区间，令 $s_i^{(t)} \in \{0, 1\}$ 表示第 t 个区间是否发放；若允许同一区间多次发放，变量就应改为计数，不能继续使用二值假设。

频率编码 (rate coding) 用观察窗口内的脉冲数量表示输入强弱。若窗口长度为 $T_{\text{win}} = K\Delta t$ ，计数与频率为

$$N_i = \sum_{t=1}^K s_i^{(t)}, \quad r_i = \frac{N_i}{T_{\text{win}}}. \quad (13.2)$$

因此，同样的脉冲数即使排列不同，也具有相同的窗口频率。将非负输入 $x_i \in [0, 1]$ 编码为每个区间独立以概率 x_i 发放，是一种教学上容易分析的随机方案。它满足 $\mathbb{E}[N_i/K] = x_i$ ，方差为 $x_i(1 - x_i)/K$ 。延长窗口可以降低这种抽样误差，但增加等待时间和期望事件数。真实神经活动未必独立，这个方差公式不应移用于任意脉冲列。

如果任务要区分“哪个信号先到”，仅统计数量会丢失关键关系。**时间编码** (temporal coding) 用发放时刻或相对时间关系承载信息。例如，**首次发放时间编码** (time-to-first-spike coding) 可以约定强输入更早发放，在窗口起点已知时令 $t_i = T_{\text{win}}(1 - x_i)$ 。也可以用相邻脉冲间隔或多个单元的相对时序编码。首次发放方案需规定没有发放时如何解码，以及时间量化、抖动和窗口起点误差如何处理；一个很早到达的脉冲并不自动具有明确含义。

图 13.1 比较相同计数、不同顺序的两组事件。频率读出无法区分它们，能够利用时刻的动态网络则可能区分。这里的“可能”还取决于突触、状态和读出是否保留了时序，而不只取决于输入带有时间戳。




图 13.1 两条构造的脉冲列在 8 个等宽时间区间内都发放 3 次，窗口频率相同，但首次发放位置和脉冲间隔不同。竖线表示事件，横轴为时间区间编号；频率读出只保留计数，时间读出还可使用排列。

输入编码与输出解码不必相同。网络可以接收时间戳事件，再用输出计数分类；也可以接收持续电流，通过输出单元的首次发放作决策。明确两

端的约定，才能比较不同方案的精度和延迟。

13.2.2 积分、泄漏与发放

图13.2将一个单元拆为突触响应、积分与泄漏、阈值检测和复位。输入事件只在到达时写入突触，突触响应与膜电位则保存连续值状态。输出脉冲反馈到复位路径，复位后的电位再经过一个时间步进入下一次积累；这条内部反馈解释了单个神经元也有记忆。




图13.2 离散脉冲神经元的计算结构。蓝色输入事件经带权突触形成输入增量 $a^{(t)}$ ，红色模块完成积分、泄漏、阈值检测和复位，黄色路径输出 $s^{(t)}$ 。下方反馈保存复位后电位 $u^{(t)}$ ，供下一步使用； $v^{(t)}$ 为复位前电位。图表示本章的更新次序，不表示细胞的解剖结构；突触自身也可保存状态，见式(13.8)。

一个输入脉冲常不足以触发输出。神经元需要累积输入，同时让旧输入的影响逐渐减弱。**膜电位**（membrane potential）是描述这种内部积累的状态变量；在简化人工模型中，它表示单元距离发放阈值还有多远，不要求逐项复现生物细胞的电化学过程。

漏积分发放模型（LIF）在两次发放之间用一阶动态描述积累与遗忘。设膜电位为 $u_i(t)$ ，静息电位为 u_{rest} ，输入电流为 $I_i(t)$ ，膜时间常数为 $\tau_m > 0$ ，电阻为 R ，则

$$\tau_m \frac{du_i(t)}{dt} = -[u_i(t) - u_{\text{rest}}] + RI_i(t). \quad (13.3)$$

无输入时，偏离静息电位的部分按 $\exp(-\Delta t/\tau_m)$ 衰减。膜电位从下方达到阈值 $\vartheta > u_{\text{rest}}$ 时，模型产生一次脉冲并复位。**不应期**（refractory period）指发放后暂时不能再次发放的时间，可通过锁定状态或禁止发放来建模。微分方程、阈值检测、复位和不应期共同决定动态，不能只给方程就认为神经元已完整定义¹¹。

为便于训练，以下把静息电位移到0，并把电流及积分系数吸收到输入

¹¹ W. Gerstner, W. M. Kistler, R. Naud, L. Paninski, *Neuronal Dynamics: From Single Neurons to Networks and Models of Cognition*, Cambridge University Press, 2014, 1st ed.

增量 $a_i^{(t)}$ 中。采用先积分、再检测、再减去阈值的离散模型：

$$v_i^{(t)} = \alpha u_i^{(t-1)} + a_i^{(t)}, \quad \alpha = \exp(-\Delta t / \tau_m), \quad (13.4)$$

$$s_i^{(t)} = H(v_i^{(t)} - \vartheta), \quad H(z) = \begin{cases} 1, & z \geq 0, \\ 0, & z < 0, \end{cases} \quad (13.5)$$

$$u_i^{(t)} = v_i^{(t)} - \vartheta s_i^{(t)}. \quad (13.6)$$

$v_i^{(t)}$ 为检测前电位, $u_i^{(t)}$ 为复位后电位, $\alpha \in (0, 1)$ 控制相邻时间步之间的保留程度。此模型每步最多发放一次; 若 $v_i^{(t)}$ 远大于阈值, 超出的电位会保留到后面, 因此它不能精确表示任意高频的连续发放。时间步、输入尺度和发放上限必须配合选择。

式(13.6)称为减法复位, 保留超过阈值的剩余电位。另一种**硬复位** (hard reset) 直接将发放后的电位设为 u_{reset} , 即 $u_i^{(t)} = (1 - s_i^{(t)})v_i^{(t)} + s_i^{(t)}u_{\text{reset}}$ 。两种复位既改变前向轨迹, 也改变反向传播。去掉泄漏、令 $\alpha = 1$, 得到离散的**积分发放模型** (integrate-and-fire, IF); 增加适应变量或非线性电位项, 可以描述更丰富的发放模式。模型越复杂, 需要存储和更新的状态越多。

示例 13.1 相同输入在不同间隔下的结果 取 $\alpha = 0.8$ 、 $\vartheta = 1$ 、 $u^{(0)} = 0$, 不设不应期。输入增量 (0.6, 0.6, 0, 0.6) 依次给出检测前电位 (0.6, 1.08, 0.064, 0.6512), 输出为 (0, 1, 0, 0), 复位后电位为 (0.6, 0.08, 0.064, 0.6512)。第二步的两个近邻输入共同越过阈值, 而第四步输入与前次积累相隔更远, 不能触发发放。

若将相同的三个 0.6 改放在第 1、3、5 步, 中间输入为 0, 则检测前电位依次为 0.6, 0.48, 0.984, 0.7872, 1.22976, 只有第五步发放。总输入不变, 输出时刻却改变了。这些数值展示泄漏与事件间隔的关系, 不是生物测量或识别实验。

图 13.3 把示例的第一组输入画成轨迹。发放由检测前电位决定, 复位后的低电位则成为下一步的初始状态; 把这两个时刻混在一起会误读阈值与输出的关系。

LIF 保留了积累与遗忘, 但固定阈值不表达“刚刚频繁发放后变得较难继续发放”。可以增加适应迹 $r_i^{(t)}$, 例如

$$r_i^{(t)} = \rho r_i^{(t-1)} + s_i^{(t-1)}, \quad \vartheta_i^{(t)} = \vartheta_0 + \kappa r_i^{(t)}, \quad 0 \leq \rho < 1, \quad \kappa \geq 0. \quad (13.7)$$

过去发放暂时抬高阈值, 适应迹随后衰减; 替换式(13.5)中的阈值即可形成一种适应 LIF 模型。额外状态延长动态时间尺度, 也增加反向路径和存储。更复杂的神经元可以使用适应电流、非线性膜电位或离子通道状态。例如, **自适应指数积分发放** (adaptive exponential integrate-and-fire, AdEx) 模型




图 13.3 示例 13.1 的离散 LIF 计算。蓝色竖线表示输入增量，红色实线连接检测前电位 $v^{(t)}$ ，黄色空心圆为复位后电位 $u^{(t)}$ ，虚线为阈值；第二步检测后发放并减去 1。连线帮助比较离散状态，不表示步间的连续电位轨迹。

结合膜电位的指数非线性与适应电流。表 13.2 比较这些模型保留的动态细节。

神经元模型	主要状态与发放机制	适用关注点
积分发放 (IF)	膜电位积分，阈值与复位	简化计数对应，未包含泄漏
漏积分发放 (LIF)	膜电位积累与泄漏，阈值与复位	有限时间记忆与较低单元复杂度
适应 LIF	膜电位及适应迹，动态阈值或电流	发放历史改变后续响应
自适应指数积分发放 (AdEx)	膜电位非线性及适应电流	以较少状态描述丰富发放模式
Izhikevich 模型	膜电位与恢复变量，阈值复位	以简化二维动态模拟多种放电行为
单室 Hodgkin-Huxley	膜电位与离子通道门控变量	解释动作电位产生的电流机制

表 13.2 神经元模型按保留的动态细节比较。IF 与 LIF 还需规定复位、不应期及时间离散化；表中不计另行添加的突触和延迟状态。复杂度更高的模型能表达更多细节，不自动产生更好的任务预测。

模型选择需要与问题一致。若只需积累事件形成分类分数，单室离子通道方程可能增加不必要的模拟成本；若研究动作电位波形或不同电流的作用，只报告 LIF 脉冲次数又不足以回答问题。模型参数的物理单位、输入尺度与数值步长应配套，不能在不同神经元中直接沿用同一组数值¹²。

13.2.3 网络连接与状态传播

图 13.4 比较相同单元的两组织。前馈边将事件送到下一层，每个单元的膜电位仍跨时间保留；循环边再把网络过去的发放送回当前计算。循环与非循环说明的是单元之间的拓扑，不取消单元内部的状态递推。

¹² W. Gerstner, W. M. Kistler, R. Naud, L. Paninski, *Neuronal Dynamics: From Single Neurons to Networks and Models of Cognition*, Cambridge University Press, 2014, 1st ed.




图 13.4 脉冲前馈网络与循环网络的构造性比较。圆内 u 表示各单元保存膜电位，箭头传递离散发放，黄色方框为输出读出。左图只保留层间前馈连接；右图增加使用上一时间步脉冲的循环边 U 。边还可带权重与传播延迟，图中只标出一条代表连接。神经元数和连边用于说明结构，不对应训练模型。

神经元之间的连接将发放事件变为后续单元的输入。**突触** (synapse) 在这里指带权连接及其对接收状态的作用。最简单的离散突触把一个到达脉冲转为电位增量 $w_{i,j}$ ：正权重促使接收单元接近阈值，负权重使其远离阈值。生物兴奋性、抑制性细胞对连接符号有更强约束；允许同一人工单元任意使用正负输出权重，是建模选择。

输入的作用还可以延续多个时间步。设一层有 m 个神经元，上层有 d 个，突触状态为 $\mathbf{q}^{(t)} \in \mathbb{R}^m$ ，前馈权重为 $\mathbf{W} \in \mathbb{R}^{m \times d}$ ，循环权重为 $\mathbf{U} \in \mathbb{R}^{m \times m}$ ，偏置为 $\mathbf{b} \in \mathbb{R}^m$ ，可写为

$$\mathbf{q}^{(t)} = \beta \mathbf{q}^{(t-1)} + \mathbf{W} \mathbf{s}_{\text{in}}^{(t)} + \mathbf{U} \mathbf{s}^{(t-1)} + \mathbf{b}, \quad \mathbf{a}^{(t)} = \mathbf{q}^{(t)}, \quad (13.8)$$

其中 $\beta \in [0, 1)$ 控制突触响应的衰减。脉冲是瞬时输入， $\mathbf{q}^{(t)}$ 与 $\mathbf{u}^{(t)}$ 却可以继续保存历史。使用上一时间步的循环脉冲避免同一步的代数环；前馈层则可按层顺序读取本步输入。

更一般地，令 $d_{i,j} \in \{0, 1, 2, \dots\}$ 表示边 $j \rightarrow i$ 的总传播延迟，以离散时间步计，实际延迟为 $d_{i,j} \Delta t$ 。权重为 $w_{i,j}$ 的边贡献 $w_{i,j} s_j^{(t-d_{i,j})}$ ；式(13.8)中的前馈边对应 $d_{i,j} = 0$ ，循环边对应 $d_{i,j} = 1$ 。为保持显式更新，每个反馈回路的总延迟必须至少为一步；零延迟边组成的子图必须无环，才能按拓扑顺序读取本步已经算出的脉冲。若允许零延迟自反馈，例如 $s = H(2s - 1)$ ，则 $s = 0$ 与 $s = 1$ 都满足方程，已知历史就不能唯一决定本步输出。实现还需维护尚未到达的事件，并为序列起点以前的脉冲指定初始历史。

即使没有循环边，脉冲神经元本身也有跨时间状态，所以脉冲前馈网络不是无记忆的逐帧映射。加入循环边后，状态既保存本单元的积累，又接

收其他单元的历史发放。初始状态、序列边界、延迟和同时到达事件的处理次序都属于模型定义；独立样本常重置状态，持续流则通常保留状态。

13.3 参数学习

给定发放机制后，还需要决定怎样调整连接，使输出与任务相符。三条路线使用的信息不同：局部规则根据相邻活动更新突触；端到端训练根据任务损失调整参数；转换方法先学习连续值网络，再把它的激活解释为脉冲统计量。它们可以组合，但优化的对象和误差来源不能混同。

下面的基本例子把泄漏、阈值和时间常数视为已给定参数，主要学习连接权重与读出。也可以学习这些动态参数，例如用 Sigmoid 参数化泄漏因子、用正值变换参数化阈值，以维持模型约束；此时梯度还要沿相应动态路径传播。整数传播延迟不能直接按普通实数参数求导，需另行设计搜索或可微近似。

13.3.1 局部可塑性规则

如果只允许一个突触读取连接两端的的活动，更新就无法直接使用全网反向传播的误差信号。**赫布学习** (Hebbian learning) 根据输入端与输出端的共同活动调整连接，表达“共同活跃时加强联系”的局部相关性思想。一个简化规则为 $\Delta w_{i,j} = \eta x_j y_i$ ，其中 x_j, y_i 是同一观察窗口的活动量， $\eta > 0$ 为更新系数。持续相关活动可能令权重不断增大，因此通常还需衰减、归一化、竞争或上下界。

共同活动的窗口并没有区分先后。**脉冲时序依赖可塑性** (spike-timing-dependent plasticity, STDP) 进一步依据突触前后发放的时间差更新权重。令 $\Delta t = t_{\text{post}} - t_{\text{pre}}$ ，一种典型的成对教学规则为

$$\Delta w_{i,j} = \begin{cases} A_+ \exp(-\Delta t / \tau_+), & \Delta t > 0, \\ -A_- \exp(\Delta t / \tau_-), & \Delta t < 0, \end{cases} \quad (13.9)$$

其中 $A_+, A_- > 0$ 为幅度， $\tau_+, \tau_- > 0$ 为时间尺度，同时发放时另定规则。该形式把“输入先到、输出随后发生”与相反次序区分开。实验中的变化还取决于细胞类型、突触强度和发放组合，不能把这条成对指数曲线当成全部生物可塑性的统一规律¹³。

局部计算不必保存所有事件对。可以用指数衰减的活动迹记录近期发放，突触后发放时读取突触前迹来加强权重，突触前发放时读取突触后迹来减弱权重。采用所有配对还是最近邻配对、权重是否有界，会产生不同学习动态。

局部相关性与分类正确率仍有距离：频繁共同出现的输入未必是区分

¹³ G.-q. Bi, M.-m. Poo, *Synaptic Modifications in Cultured Hippocampal Neurons: Dependence on Spike Timing, Synaptic Strength, and Postsynaptic Cell Type* In The Journal of Neuroscience, 1998, vol. 18, no. 24, pp. 10464–10472

标签所需的特征。为把局部活动与任务结果连接，可加入第三个调制信号，令 $\Delta w_{i,j} = \eta m^{(t)} e_{i,j}^{(t)}$ 。其中 $e_{i,j}^{(t)}$ 是记录近期局部活动及可更新程度的**资格迹** (eligibility trace)， $m^{(t)}$ 传递奖励、误差或其他全局调制。第三因素能改变更新方向和时机，但它是否等价于目标函数梯度，还要检查调制信号和资格迹的具体构造¹⁴。

13.3.2 替代梯度与时间反向传播

监督任务需要将输出误差分配到多层连接。设每个样本含 K 步输入脉冲，标签为 y ，输出读数为 $\mathbf{z} = K^{-1} \sum_t \mathbf{s}_{\text{out}}^{(t)}$ ，可以用 $\ell(\mathbf{z}, y)$ 训练分类器。其他读出可使用膜电位、过滤后的输出或发放时间；读出改变时，损失及其求导也应同步改变。

困难在式(13.5)的阶跃函数。 H 在阈值之外的普通导数为 0，阈值处不连续。直接将其导数带入链式法则，几乎处处得不到能调整发放的信号；小幅改变权重还可能在越过阈值时突然改变整条轨迹。**替代梯度** (surrogate gradient) 在前向计算中保留离散发放，在反向计算中用一个有限、非零的函数代替阶跃导数。例如，令 $z = v - \vartheta$ ，使用

$$\frac{\partial s}{\partial v} \rightsquigarrow \psi(z) = \frac{c}{(1 + \kappa|z|)^2}, \quad c, \kappa > 0. \quad (13.10)$$

符号 $\rightsquigarrow$ 表示指定替代规则，不表示真实导数相等。靠近阈值的单元收到较强训练信号，远离阈值的单元收到较弱信号。 c 改变梯度幅度， κ 改变有效宽度；两者与阈值及电位尺度有关¹⁵。

替代规则也进入复位的导数。对本章的减法复位，若不停止复位路径的求导，有

$$\frac{\partial u_i^{(t)}}{\partial v_i^{(t)}} \rightsquigarrow 1 - \vartheta \psi(v_i^{(t)} - \vartheta). \quad (13.11)$$

若实现中把复位脉冲视为常数，这个导数改为 1。它们前向相同，反向却不同；硬复位的表达式也要单独求导。说明训练方法时，应明确复位是否参与反向计算，不能只写“使用替代梯度”。

将 $\mathbf{q}^{(t)}$ 、 $\mathbf{u}^{(t)}$ 和所需延迟状态合并为 $\mathbf{h}^{(t)}$ ，网络可写为 $\mathbf{h}^{(t)} = F_{\theta}(\mathbf{h}^{(t-1)}, \mathbf{x}_t)$ 。第10章的时间展开和共享参数梯度累积因此仍然适用。区别在于发放及相关路径的局部导数由替代规则指定。梯度需要跨层和跨时间传播，较长窗口增加激活存储，截断展开则遗漏被切断的历史影响。替代梯度通常既不是原离散网络损失的精确梯度，也不保证是某个统一平滑目标的梯度；它是一种有用但需要验证的学习近似。

¹⁴ W. Gerstner, M. Lehmann, V. Liakoni, D. Corneil, J. Brea, *Eligibility Traces and Plasticity on Behavioral Time Scales: Experimental Support of NeoHebbian Three-Factor Learning Rules* In *Frontiers in Neural Circuits*, 2018, vol. 12, 53

¹⁵ E. O. Neftci, H. Mostafa, F. Zenke, *Surrogate Gradient Learning in Spiking Neural Networks: Bringing the Power of Gradient-Based Optimization to Spiking Neural Networks* In *IEEE Signal Processing Magazine*, 2019, vol. 36, no. 6, pp. 51–63

算法 13.1 脉冲网络的监督训练

输入： 输入序列与标签、时间步数 K 、神经元参数、替代规则 ψ

输出： 学得的权重与读出参数

```

1: for 每个训练小批量 do
2:   按样本边界设置膜电位、突触状态和延迟队列
3:   for  $t = 1, \dots, K$  do
4:     计算突触输入，按式(13.4)–(13.6)更新各层
5:     保存反向计算所需状态并积累输出读出
6:   end for
7:   由读出与标签计算损失
8:   沿展开图反向计算，以  $\psi$  代替发放导数并采用约定的复位导数
9:   累积共享参数梯度，必要时裁剪，再更新参数
10: end for

```

13.3.3 人工网络到脉冲网络的转换

频率编码提供了另一条学习路径：先训练具有非负激活的连续值网络，再用发放率近似这些激活。**人工网络到脉冲网络转换** (ANN-to-SNN conversion) 就是建立连续激活与脉冲统计量的对应，以复用已经学得的权重。理解这一对应，可以从不泄漏的积分发放模型开始。

设 $\alpha = 1$ 、 $u^{(0)} = 0$ ，采用减法复位，每步输入增量为 $a^{(t)}$ ，将 K 次状态更新求和得

$$\vartheta \sum_{t=1}^K s^{(t)} = \sum_{t=1}^K a^{(t)} - u^{(K)}. \quad (13.12)$$

若输入非负且每步不超过 ϑ ，则 $0 \leq u^{(K)} < \vartheta$ ，于是

$$0 \leq \frac{1}{K} \sum_{t=1}^K a^{(t)} - \frac{\vartheta}{K} \sum_{t=1}^K s^{(t)} < \frac{\vartheta}{K}. \quad (13.13)$$

这说明阈值乘以平均发放量可以近似平均输入，剩余电位造成有限窗口误差。比如恒定输入 0.3、阈值 1、窗口 4 步，只发放 1 次，对应平均值 0.25，尚有 0.2 电位未释放。窗口 10 步恰好发放 3 次，对应 0.3。这里是输入已校准的单神经元结论，不能直接作为多层网络的统一误差界。

实际转换需处理负激活、偏置、归一化和不同层的尺度。对线性层 $\mathbf{W}\mathbf{x} + \mathbf{b}$ ，若训练后的 BatchNorm 使用固定均值 μ 和方差 σ^2 ，它的仿射变换可以折叠到权重与偏置。对输出通道 i ，有 $\mathbf{W}'_{i,:} = \gamma_i \mathbf{W}_{i,:} / \sqrt{\sigma_i^2 + \epsilon}$ ， $b'_i = \gamma_i(b_i - \mu_i) / \sqrt{\sigma_i^2 + \epsilon} + \zeta_i$ 。这里 γ_i, ζ_i 为归一化的缩放和偏移，折叠使用推理统计量。阈值或层权重再依据代表性校准数据调节，使常见激活既不会长期静默，也不会超出单步发放上限¹⁶。

加入泄漏后，式(13.12)会多出遗忘项；采用硬复位还会丢弃超阈值的剩

¹⁶ B. Rueckauer, I.-A. Lungu, Y. Hu, M. Pfeiffer, S.-C. Liu, *Conversion of Continuous-Valued Deep Networks to Efficient Event-Driven Networks for Image Classification* In *Frontiers in Neuroscience*, 2017, vol. 11, 682

余电位。多层的有限窗口误差、上游发放延迟和统计尺度偏差都可能累积。转换适合能够由非负发放统计量近似的计算；若目标依赖精确相对时序，仅保留连续激活的频率对应通常不够。端到端脉冲训练则可以直接针对目标窗口和读出来调整动态。

13.4 理论分析

13.4.1 时序表达与动态稳定性

脉冲网络能否区分输入，需要同时考察编码、状态和读出。若编码只给出窗口计数，原始时间顺序已经丢失，后续网络无法从计数恢复它。若编码保留时刻，有限时间常数又可能让相隔很远的事件互不影响。即使内部状态不同，最终只做总计数的读出也可能把两条轨迹合并。表达能力属于整个输入到输出的映射，不能只数神经元或脉冲模式。

在不跨越阈值、发放模式固定的区间，LIF 状态差异会按泄漏因子衰减：相同后续输入下，单元满足 $\delta u^{(t)} = \alpha \delta u^{(t-1)}$ 。但阈值附近的小扰动可能使某一步多发放一次，继而改变复位、突触输入和后续事件。因而 $\alpha < 1$ 只说明无发放切换时的泄漏稳定性，不足以保证整个循环脉冲网络全局收缩。

分析一段固定发放模式内的连续状态递推，可以像第10章一样检查局部雅可比连乘。遇到阈值切换时，还需处理不连续映射、事件时刻的变化和复位。训练用的替代雅可比则描述指定的反向规则，不能直接用它证明真实离散动态的稳定性。较强泄漏有利于忘记过时状态，也缩短可利用的历史；循环反馈、延迟和适应状态可以改变这种取舍。

13.4.2 精度、延迟与事件数量

时间离散化和编码共同决定可表示的精度。若用 K 步中的脉冲比例表示 $[0, 1]$ 内数值，读出的间隔为 $1/K$ ；随机编码还叠加抽样方差。首次发放编码可以只用一个事件表示多个时间位置，但接收端必须等待该事件，并能区分这些位置。减少事件数与缩短决策时间是两个不同目标。

设一次推理中神经元 j 发放 N_j 次，连接到 d_j 个接收突触，若每次发放都访问这些连接，则触发的突触累加数为

$$C_{\text{syn}} = \sum_j N_j d_j. \quad (13.14)$$

这个量比“发放次数”更接近通信和突触处理成本。一个发放稀少却有大量扇出的单元，仍可能触发很多操作。按时间步模拟 m 个状态单元还需 $O(Km)$ 次状态更新，若实现为稠密矩阵计算，未发放的连接也未必被跳过。事件驱动实现可以在到达事件时更新部分状态，但仍需处理泄漏、内部发放和延迟队列。

因此, SNN 的能耗不能由二值输出或事件数单独推出。评估应同时给出任务质量、观察窗口、决策延迟、突触访问量、状态存储及实际设备上的能耗。与连续值网络比较时, 还要统一输入预处理和决策条件。稀疏事件提供节省操作的机会, 最终收益取决于数据活动、网络连接和硬件是否能利用这种稀疏性。

13.5 常见应用

13.5.1 事件流识别

变化驱动的视觉传感器为脉冲网络提供了直接的事件输入。**事件相机** (event camera) 在像素亮度变化达到阈值时输出位置、时刻和变化方向, 而非在固定间隔输出整帧图像。一个样本可表示为事件序列 $\{(x_k, y_k, t_k, p_k)\}_{k=1}^{n_e}$, 其中 (x_k, y_k) 为像素坐标, t_k 为时间戳, $p_k \in \{-1, 1\}$ 为亮度变化极性。事件说明变化, 并不直接给出完整的绝对亮度图像¹⁷。

以动作片段分类为例, 可以按像素和极性分输入通道, 将时间戳划入宽度 Δt 的区间, 得到输入脉冲张量。如果同一像素在一个区间多次触发, 可采用事件计数, 或缩短区间以保留二值表示; 合并事件会改变信息。空间卷积连接提取局部变化模式, 膜电位与突触状态累积时间关系, 再用类别输出单元的计数或连续读出产生分数。

若类别 c 的计数为 N_c , 可以取 $z_c = N_c/K$ 并用 Softmax 交叉熵训练, 预测为 $\arg \max_c z_c$; 所有计数为 0 时要规定平局处理或继续观察。损失可以只在片段结束计算, 也可以在多个截断窗口计算以训练较早输出。后者需要固定评价时刻, 避免把使用更多未来事件的模型与早期决策模型直接比较。

数据划分应以独立动作片段、主体或采集场景为单位, 不能把同一连续记录切出的相邻窗口随机分到训练和测试中。事件噪声、场景变化与传感器阈值都会改变输入分布, 识别结果须在规定的时间预算下评估。

13.5.2 连续感知与动态响应

持续感知没有天然的片段终点。网络接收不断到来的变化, 保留状态, 并在预定时刻或满足决策条件时产生输出。比如一个教学性的运动方向检测器可以用两组位置通道接收事件, 利用不同突触延迟使某一方向的事件在下游同时到达; 相反方向则不形成同样的时间重合。LIF 的积累与阈值把这种重合转为发放, 方向读出据此给出分数。

连续输出也可以从过滤后的状态得到。设 m 维输出脉冲为 $\mathbf{s}^{(t)}$, 令 $\mathbf{r}^{(t)} = \rho \mathbf{r}^{(t-1)} + (1 - \rho) \mathbf{s}^{(t)}$, $\rho \in [0, 1)$, 再用 $\hat{\mathbf{y}}^{(t)} = \mathbf{C} \mathbf{r}^{(t)} + \mathbf{d}$ 预测连续量。 ρ 越大, 输出越平滑, 也越迟缓; 用膜电位读出则会保留阈值以下的状态。输出形

¹⁷ P. Lichtsteiner, C. Posch, T. Delbruck, A 128 × 128 120 dB 15 μ s Latency Asynchronous Temporal Contrast Vision Sensor In IEEE Journal of Solid-State Circuits, 2008, vol. 43, no. 2, pp. 566–576

式应服从任务对响应速度、抖动和置信度的要求。

持续状态还会带来边界问题。静默期间应让历史影响按模型衰减；传感器重启、场景切换或长时间中断后，可以按明确规则重置状态。训练时若每个短窗口都重置，使用时却无限保留状态，网络面对的状态分布可能不同。保留跨窗口状态时，也要说明哪些梯度被截断，不能把跨窗口记忆误认为已经完成跨窗口信用分配。

13.6 本章小结

SNN 以离散发放通信、以连续状态保存历史，编码、突触、泄漏、阈值与读出共同形成预测。局部规则、替代梯度和网络转换分别利用相邻活动、近似任务梯度与发放统计对应。较长窗口能改善部分编码精度，也增加延迟与操作；实际收益仍须连同输入编码、突触访问、状态更新和设备测量判断。

神经网络的训练

反向传播给出了参数梯度，但“能算出梯度”与“能有效训练”之间仍有距离。同一网络可能在某个步长下振荡，在另一个步长下进展缓慢；换一个批量大小，更新噪声又会改变。增加层数或时间长度后，损失仍可计算，早期层却可能收不到足够的学习信号。要处理这些问题，需要同时考察目标函数的局部形状、梯度估计，以及网络怎样传递信息。

前面各模型章已经说明其特有的求导过程。本章在共同的参数空间中讨论更新方法，再从表示尺度、连接路径和参数化三个方面解释如何改善训练。优化器、归一化和网络结构往往共同起作用，但它们改变的是不同对象：优化器改变参数更新，归一化改变前向计算和相应导数，连接结构则改变信息可以经过的路径。训练误差能否降低属于本章问题，所得解在新数据上怎样表现由第15章进一步讨论。

设训练集为 $\{(\mathbf{x}_i, y_i)\}_{i=1}^n$ ，所有可训练参数展平为 $\boldsymbol{\theta} \in \mathbb{R}^p$ ，经验目标为

$$\mathcal{L}(\boldsymbol{\theta}) = \frac{1}{n} \sum_{i=1}^n \ell(f_{\boldsymbol{\theta}}(\mathbf{x}_i), y_i). \quad (14.1)$$

这里 p 是参数数目， n 是样本数。第 t 次更新在 $\boldsymbol{\theta}^{(t-1)}$ 处计算梯度或其估计 $\mathbf{g}^{(t)}$ ，再得到 $\boldsymbol{\theta}^{(t)}$ 。除非另行说明，公式中的平方、开方和除法作用于向量各元素；矩阵的逆和矩阵幂会明确指出。

14.1 主要挑战

第二卷“基础、理论和可信性”的“深度学习的可学习性”章讨论了网络在给定参数、初始梯度或学习规则下何时可学习；这些结论都需要相应条件。实际训练受阻时，要先辨认是目标形状、估计噪声还是传播路径不满足预期，再选择后面的改进方法。

14.1.1 局部极小点与鞍点

凸学习中的全局下降结论不能直接用于一般多层网络，第二卷“基础、理论和可信性”的“一般学习的可学习性”章“非凸学习问题”节已说明非凸分析为何需要区分驻点与目标值。这里先判断“小梯度”究竟代表什么，后面才能理解扰动、曲率修正与步长控制的用途。以下先讨论可微目标的内部点；ReLU 折点等不可微位置需要使用相应的非光滑分析。

驻点 (stationary point) 是梯度为 0 的位置：一阶信息没有指出下降方向。**局部极小点** (local minimum) 是在某个邻域内没有更低目标值的位置；若除该点外的邻近位置都更高，则是严格局部极小点。**全局极小点** (global minimum) 要求整个参数范围内都没有更低值，因而也是局部极小点。局部极小却不一定全局最小，它的训练误差也可能仍然很高。**局部极大点** (local maximum) 则在邻域内没有更高值。可微内部极值都是驻点，但驻点还可以是极值以外的点。

在目标二阶可微的位置，**Hessian 矩阵** (Hessian matrix) $\mathbf{H} = \nabla^2 \mathcal{L}(\theta)$ 描述局部曲率，即不同方向的梯度怎样随参数改变。驻点处若 $\mathbf{H}$ 正定，该点是严格局部极小点；若负定，则是严格局部极大点。若同时有正、负特征值，就存在上升和下降方向，属于**鞍点** (saddle point)：从某些方向看像谷底，从另一些方向看却像山顶。正半定只是局部极小的必要条件，不能单独保证极小。零特征值使二阶判断不充分，例如 x^4 、 $-x^4$ 与 x^3 在 0 处都有零梯度、零二阶导数，却分别是极小、极大与非极值驻点。

图 14.1 把“梯度为 0”和“周围怎样变化”分开显示。左上图两个谷底都满足局部极小定义，右侧谷底更低；其间的峰在截面内是极大，在完整二维目标中却沿 y 方向上升，因此是鞍点。其余三个曲面强调：站在中心时梯度都为 0，但离开中心后，可能处处上升、处处下降，或随方向而异。

训练为何会遇到这些形状，可以从最简单的两层线性模型看起。令标量预测为 uv 、目标为 1，平方损失为

$$\mathcal{L}(u, v) = \frac{1}{2}(uv - 1)^2, \quad \nabla \mathcal{L} = (uv - 1)(v, u)^\top. \quad (14.2)$$

损失对预测 uv 是凸的，对两层参数 (u, v) 却不是。在 $(0, 0)$ 处，梯度为 0、损失为 $1/2$ ，Hessian 的两个特征值为 1 和 -1 。沿 $u = v$ 的小扰动降低损失，沿 $u = -v$ 则提高损失；只沿任一坐标轴观察，损失还保持不变。多层参数的乘积、激活的非线性以及样本损失的叠加，会形成更复杂的目标几何，凸的输出损失并不能消除这种参数非凸性。

平坦区域 (flat region) 指在所考察尺度内目标或梯度变化很小的区域，不必包含严格驻点。饱和和激活、参数冗余或近似对称性都可能产生这类区域。小梯度可能意味着接近一个解，也可能意味着处在几乎没有推进信号的位置；需要同时检查损失值、梯度尺度和邻近更新的效果。




图 14.1 驻点与极值的构造示意。(a) 为 $F(x, y) = 1 + (x^2 - 1)^2 + 0.8(x^3/3 - x) + y^2$ 的 $y = 0$ 截面。 $(-1, 0)$ 是非全局局部极小， $(1, 0)$ 是全局极小，方点 $(-0.2, 0)$ 是完整曲面的鞍点。(b) $f = x^2 + y^2$ ；(c) $f = -x^2 - y^2$ ；(d) $f = x^2 - y^2$ 。后三图黄色中心点均为驻点，蓝色实线表示上升切片，红色线表示下降切片。图示为解析函数，不是网络损失的实测图。

梯度下降若精确到达零梯度驻点，就没有一阶更新；在其附近，梯度很小也会让推进缓慢。鞍点还有可下降方向，但小梯度未必明显指向它；非全局局部极小则需要离开当前邻域才能到达更低区域。高维鞍点及其附近平台的研究说明，训练停滞不能一概归因于“掉进了坏的局部极小”，这类现象应结合局部曲率判断¹。

随机扰动可能使优化离开某些鞍点或平台，但若噪声没有相应方向分量，或在零参数处每个样本的梯度都为 0，SGD 也不会自动产生逃离信号。网络中的参数置换和尺度对称性还会使同一函数对应许多参数位置，因此极小点数量本身不能说明函数质量。驻点性质、训练误差与泛化风险是三种不同判断。

¹ Y. N. Dauphin, R. Pascanu, C. Gulcehre, K. Cho, S. Ganguli, Y. Bengio, *Identifying and Attacking the Saddle Point Problem in High-Dimensional Non-Convex Optimization* In *Advances in Neural Information Processing Systems* 27, 2014, pp. 2933–2941

14.1.2 病态曲率

第二卷“基础、理论和可信性”的“深度学习的可学习性”章中的分解参数梯度流公式展示了分解参数化如何改变网络的更新动力学；即使目标函数很简单，不同方向的尺度也能拖慢训练。这个问题引出动量、预条件及后面的尺度重参数化。即使只有一个全局极小点，更新也可能很困难。考虑教学目标

$$q(\theta) = \frac{1}{2}(a\theta_1^2 + b\theta_2^2), \quad a \gg b > 0. \quad (14.3)$$

两个方向分别以 a 和 b 的尺度变化。固定步长梯度下降在第一个方向的系数为 $1 - \eta a$ ，在第二个方向为 $1 - \eta b$ 。要让任意初始位置的两个方向都收缩，必须取 $0 < \eta < 2/a$ ；这个步长在缓方向却只能带来很小的变化。

病态曲率 (ill-conditioned curvature) 描述不同方向的曲率尺度相差很大的情形。正定二次目标的**条件数** (condition number) 为 $\kappa = \lambda_{\max}(\mathbf{H})/\lambda_{\min}(\mathbf{H})$ 。在该模型中，最优固定步长 $2/(a+b)$ 对应的最坏方向收缩因子为 $(\kappa - 1)/(\kappa + 1)$ ，条件数大时接近 1。若步长让陡方向的系数为负，参数会交替越过谷底，表现为振荡。

取 $a = 100, b = 1, \eta = 0.015$ ，陡方向每步乘以 -0.5 ，缓方向每步乘以 0.985 。图 14.2 左图显示这个稳定步长下的轨迹：左右振荡迅速缩小，轨迹落到谷底附近，但第 80 步仍未到达极小点。此时是收敛慢，继续迭代仍会趋向原点。

为了加快缓方向，若把步长增到临界值 $\eta = 2/a = 0.02$ ，陡方向系数就变为 -1 。右图从上方观察同一谷地： $\theta_1^{(t)} = 0.35(-1)^t$ 一直在两侧来回切换， $\theta_2^{(t)} = 0.98^t$ 虽然逐渐减小，却不能带动陡方向的摆幅收缩。损失趋向 $100 \times 0.35^2/2 = 6.125$ ，而最小值是 0；这时增加迭代次数也无法收敛到原点。步长再大还会发散。两图共同显示了单一全局步长的矛盾：照顾陡方向时缓方向走得慢，试图加快缓方向又可能在陡方向越过头。动量利用历史方向缓解某些振荡，**预条件** (preconditioning) 则通过矩阵或逐坐标尺

度变换，让更新适应不同方向的变化速度。




图 14.2 同一病态二次目标在两种步长下的轨迹，标题直接标出条件数 $\kappa = a/b = 100$ ，黄色点为极小点。(a) 三维图采用稳定步长 0.015，蓝色实心圆标出第 0-8 步，空心圆标出第 80 步；陡方向收缩快，谷底推进慢。(b) 俯视投影采用临界步长 0.02，深红线连接第 0-20 步，实心圆标出第 0-6 步，空心圆为第 20 步；灰线为等高线，竖虚线为谷底。左右摆幅保持 0.35，损失趋向 6.125 而无法达到原点处的 0。

条件数依赖参数坐标。在同一函数上重缩放参数，可以改变 Hessian 的特征值与梯度下降轨迹；归一化和重参数化因此可能影响优化。非凸目标的 Hessian 还可能不正定，此时不能直接套用上面的正定条件数及收缩结论，需要按当前区域分析。

14.1.3 非精确梯度

第二卷“基础、理论和可信性”的“一般学习的可学习性”章“凸学习问题的随机梯度下降”小节的分析需要明确抽样、步长与损失条件；实际更新中的方差和偏差也必须分别辨认。批量调整、历史平均和梯度修正分别处理其中不同部分。完整训练集的梯度需要访问全部样本。小批量训练只选 b 个样本组成索引集合 $B^{(t)}$ ，计算

$$\mathbf{g}^{(t)} = \frac{1}{b} \sum_{i \in B^{(t)}} \nabla_{\boldsymbol{\theta}} \ell(f_{\boldsymbol{\theta}^{(t-1)}}(\mathbf{x}_i), y_i). \quad (14.4)$$

若在给定当前参数后独立、均匀、有放回抽样，条件期望等于完整经验梯度。独立抽样下，其协方差为单样本梯度协方差的 $1/b$ ；无放回抽样还有有限总体修正。按顺序遍历一段相关视频，或在一个轮次内随机重排后逐

批读取，并不满足这一条件独立模型。

随机方差 (stochastic variance) 描述梯度估计围绕期望的波动，**系统性偏差** (systematic bias) 则是估计期望与目标梯度的差异。扩大独立批量可以降低方差，却不能消除截断时间反向传播遗漏历史路径的偏差，也不能纠正错误的损失缩放。量化、有限精度和近似算子还会引入数值误差，是否具有偏差取决于具体实现。

梯度累积可以把多个小批量的梯度合成为较大批量更新，但要求它们在同一参数位置计算，并按样本数或有效词元数正确加权。BatchNorm 等依赖当前批量的操作、随机失活及不同长度掩码，会使“分批累积”与“一次大批量前向”具有不同计算图。批量大小还同时改变每轮更新次数，比较时应区分相同更新步数、相同样本访问量与相同时间预算。

14.1.4 梯度传播与长期依赖

前面模型章中的反向传播都遵循链式法则，训练困难可能出在这条链的内部。残差、门控、初始化与参数约束之所以能参与改善训练，是因为它们改变下面连乘中的路径或因子。梯度误差来自估计过程，梯度过小还可能来自计算图本身。对于 L 层复合映射，记 $\mathbf{J}_l = \partial \mathbf{h}^{(l)} / \partial \mathbf{h}^{(l-1)}$ ，若梯度按列向量表示，则

$$\nabla_{\mathbf{h}^{(s)}} \ell = \mathbf{J}_{s+1}^T \cdots \mathbf{J}_L^T \nabla_{\mathbf{h}^{(L)}} \ell. \quad (14.5)$$

沿某些方向反复缩小，会形成**梯度消失** (vanishing gradients)；反复放大，则可能形成**梯度爆炸** (exploding gradients)。算子范数给出上界 $\|\nabla_{\mathbf{h}^{(s)}} \ell\|_2 \leq \prod_{l>s} \|\mathbf{J}_l\|_2 \|\nabla_{\mathbf{h}^{(L)}} \ell\|_2$ 。这个上界不能反过来证明所有梯度方向都爆炸，实际方向、奇异向量对齐和抵消同样重要。

循环网络沿时间重复使用状态映射，出现同类雅可比连乘。饱和激活的小导数、权重尺度、网络深度和递推长度都会影响传播。裁剪可以限制已经算出的异常大梯度，不能恢复已经衰减到接近 0 的历史信号。另一方面，状态保存了某个输入的信息，也不保证损失能沿该信息的路径训练早期参数：前向记忆与反向信用分配需要分别检查。

14.2 优化方法

一次参数更新需要决定往哪里走、走多远，以及当前梯度有多少可以信任。第14.1节的目标几何、病态曲率和非精确梯度，分别给这三个决定带来困难。优化方法希望改善的性质可以据此列出：

- **下降方向**。负的完整梯度给出欧氏坐标下的局部最陡下降方向，但弯曲谷地中沿这个方向反复更新可能绕路；小批量梯度还会偏离完整目标的方向。动量借助历史判断持续趋势，预条件和曲率方法利用方向间的

耦合修正更新。小梯度区域还需辨别极小、鞍点与平台，不能把“方向信号弱”直接当作“已找到好解”。

- **下降尺度。**步长过小会让训练长时间停留在高损失区，过大又可能跨过谷底、持续振荡甚至发散。希望方法同时管理整体学习率和不同方向的相对尺度，在缓方向充分推进，在陡方向限制更新，并随训练阶段减小需要精细调整时的步幅。调度、逐坐标缩放、阻尼和步长搜索分别处理这些尺度选择。
- **噪声适应。**小批量梯度会随样本改变，异常大值、稀疏访问和非平稳统计又会使历史参照失准。批量平均、历史平滑、遗忘机制与裁剪可以控制其中不同部分；过强平滑会滞后，过大步长会放大噪声，过快遗忘则难以识别趋势。降低方差也不能自动消除截断计算或错误缩放造成的偏差。

方向与尺度需要一起判断。精确下降方向也可能因步长过大而提高损失，较小更新则可能只是停滞。更复杂的估计还会增加求解、通信和历史状态，因此要比较达到同一训练目标的总时间与峰值存储。非凸目标上的这些改进依赖相应条件；计算图内部已经消失的梯度，仍需在第14.4节改善传播路径，泛化表现则由第15章另行判断。

为了比较不同方法，可以把优化器看成一个带记忆的更新过程：接收当前位置的信息，读取历史状态，按规则计算参数增量，再保存下一步需要的状态。分类维度来自这个过程的四个组成部分：

- **输入。**基本方法接收当前参数与完整或抽样梯度；曲率方法还使用 Hessian、输出雅可比或 Fisher 相关信息，步长搜索还需评估候选位置的损失。输入的精度、抽样方式和获取成本，限定了方法能作出怎样的判断。
- **状态。**无动量 SGD 不保存与参数同规模的历史缓冲；动量保存方向，AdaGrad 与 RMSProp 保存平方梯度统计，Adam 同时保存两种矩，L-BFGS 保存有限组参数差与梯度差。状态还可能是分层矩阵、行列因子和调度进度，其大小与遗忘方式决定成本和适应速度。
- **方法。**可直接沿梯度缩放，也可先平滑方向、按坐标调整尺度、求解耦合方向的线性系统，或提取符号、整形奇异值。裁剪、阻尼、偏差修正与学习率调度可以参与这个计算；近似方式决定保留哪些关系、舍弃哪些信息。
- **输出。**对训练循环而言，输出是参数增量 $\Delta\theta^{(t)}$ 或等价的新参数，以及更新后的历史状态。比较增量的方向、长度、坐标间比例和约束可行性，才能看出前三个维度最终怎样影响训练；梯度范数受限不意味着参数增量也有同一上限。

这四个维度描述同一个优化器，可以交叉组合。例如，SGD 以当前梯度为输入、没有方向历史，方法是乘以学习率，输出 $\Delta\theta^{(t)} = -\eta_t \mathbf{g}^{(t)}$ ；Adam 仍以当前梯度为主要输入，却用两种历史状态构造平滑方向与逐坐标尺度，因此输出的方向和长度都可能不同。仅说“使用一阶梯度”不能区分二者，仅说“保存平方统计”也不能把这种状态当作 Hessian。

下面沿这个共同过程展开：基本更新、调度和裁剪建立基准；动量与自适应方法增加历史状态；牛顿、拟牛顿、GGN 和自然梯度使用更强的几何信息或估计；K-FAC、Shampoo 和 Muon 利用层或矩阵结构改变计算与输出。每种方法都要连同输入、状态、计算规则 and 实际增量判断，而不能只凭“二阶”或“自适应”名称归类。

在共同记号下，可将许多更新写为 $\theta^{(t)} = \theta^{(t-1)} - \eta_t \mathbf{P}^{(t)} \mathbf{d}^{(t)}$ 。 $\mathbf{d}^{(t)}$ 由当前梯度及历史信息构成， $\mathbf{P}^{(t)}$ 为尺度变换或预条件矩阵， η_t 为全局学习率。这个分解帮助辨认方法改变了方向、逐坐标尺度，还是随训练进程变化的整体步长；并非所有优化器都必须显式构造 $\mathbf{P}^{(t)}$ 。

14.2.1 梯度下降与随机梯度下降

先不增加历史状态或曲率近似，只沿当前梯度更新，便能看清步长、光滑性和抽样噪声之间的基本关系。后面的方法都需要以这个基准区分自己改变了哪个部分。**梯度下降** (gradient descent) 使用完整目标梯度；**随机梯度下降** (stochastic gradient descent, SGD) 使用抽样梯度，小批量版本以多个样本平均。它们的基本更新都是

$$\theta^{(t)} = \theta^{(t-1)} - \eta_t \mathbf{g}^{(t)}. \quad (14.6)$$

对梯度为 L_s -Lipschitz 的可微目标，完整梯度更新满足

$$\mathcal{L}(\theta - \eta \nabla \mathcal{L}) \leq \mathcal{L}(\theta) - \eta(1 - L_s \eta/2) \|\nabla \mathcal{L}\|_2^2. \quad (14.7)$$

因此 $0 < \eta < 2/L_s$ 给出这一步的下降保证。非光滑网络、随机梯度以及不满足全局光滑条件的目标，需要另外分析；实际损失不必每一步都下降。

小批量 SGD 的每一步既受到当前下降方向影响，也受到抽样噪声影响。若 $\mathbf{g} = \nabla \mathcal{L} + \xi$ 、条件均值 $\mathbb{E}\xi = \mathbf{0}$ ，代入光滑性上界并取条件期望，得到

$$\begin{aligned} \mathbb{E}[\mathcal{L}(\theta - \eta \mathbf{g}) \mid \theta] &\leq \mathcal{L}(\theta) - \eta(1 - L_s \eta/2) \|\nabla \mathcal{L}\|_2^2 \\ &\quad + \frac{1}{2} L_s \eta^2 \mathbb{E}[\|\xi\|_2^2 \mid \theta]. \end{aligned} \quad (14.8)$$

噪声项随 η^2 增长；当真实梯度很小时，它可能抵消这一步的预期下降。减小步长或扩大独立批量可以改变这项，但也改变推进速度和计算量。这解释了为什么 SGD 后期可能在解附近波动，而不是每步精确靠近极小点。

SGD 的优势是更新简单、额外状态少，小批量避免每一步遍历全部数据；完整梯度则消除了抽样方差，更便于判断局部下降。代价分别是随机波动和较高的数据访问成本，而且两者都用同一全局步长面对不同方向的曲率。一次基本更新不额外维护与 p 同规模的历史状态。比较速度时，应同时计算前向、反向和数据访问成本，而不能把“更新次数少”直接视为更快。

14.2.2 学习率调度

式(14.8)中，推进项随步长增长，噪声项却随步长平方增长；训练早期与接近解时未必需要相同尺度。调度通过改变整体步长处理这一阶段差异。**学习率调度** (learning rate scheduling) 按训练进程改变 η_t 。固定学习率维持同一更新尺度；分段衰减在预定里程碑乘以小于 1 的系数；指数衰减可以写为 $\eta_t = \eta_0 \gamma^t$, $0 < \gamma < 1$ 。若固定总训练长度，余弦调度可将学习率从 $\eta_{\max}$ 平滑降到 $\eta_{\min}$ ：

$$\eta_t = \eta_{\min} + \frac{\eta_{\max} - \eta_{\min}}{2} \left[1 + \cos \left(\frac{\pi(t - t_w)}{T - t_w} \right) \right], \quad t_w \leq t \leq T. \quad (14.9)$$

这里 T 为总更新次数， t_w 为预热结束步。**预热** (warmup) 在训练早期逐步增加学习率，例如前 t_w 步取 $\eta_t = \eta_{\max} t / t_w$ ，让初始参数和优化器统计量在较小更新下开始适应。周期性调度则反复升降，带重启的余弦调度是其中一种形式²。

调度以很小的额外成本区分早期推进与后期精细调整，预热还能限制尚未稳定的初始更新。但衰减过早可能在高损失区停滞，过晚可能延长解附近的波动；预定总长度也未必适应中途改变的预算。调度可以按更新步、样本访问量或训练轮次计时，这些单位在批量改变时不再等价。全局 η_t 决定整步的基础尺度，后面的自适应方法再调整相对尺度。预热不修复错误梯度，衰减也不保证找到全局极小点。

例如，计划训练 1000 步，前 100 步线性预热，随后用式(14.9)衰减。第 100 步恰好到达 $\eta_{\max}$ ，第 550 步为两端学习率的平均，第 1000 步到达 $\eta_{\min}$ 。若恢复第 550 步的参数却从调度起点重新计时，后续轨迹就与原计划不同。调度状态因此属于恢复训练所需的信息。

14.2.3 梯度裁剪

第14.1.4节中的连乘可能产生偶发的大梯度，数值误差也可能放大更新。裁剪直接限制已产生的信号幅度，属于更新前的控制。若偶尔出现很大的梯度，一次更新就可能破坏当前参数。**梯度裁剪** (gradient clipping, 也称梯度截断) 在应用优化器前限制梯度。逐元素裁剪令 $\tilde{g}_j = \max(-c, \min(c, g_j))$,

² I. Loshchilov, F. Hutter, *SGDR: Stochastic Gradient Descent with Warm Restarts* In International Conference on Learning Representations, 2017

$c > 0$ ，它改变部分坐标的相对比例；整体范数裁剪则为

$$\tilde{\mathbf{g}} = \mathbf{g} \min \left(1, \frac{c}{\|\mathbf{g}\|_2} \right), \quad (14.10)$$

零梯度直接保留。整体裁剪在非零时保持方向，但会引入与梯度大小有关的偏差。裁剪后的梯度还可能被动量或自适应尺度放大，所以梯度范数上限不等于最终参数步长上限。

取 $\mathbf{g} = (3, 4)^\top$ ，范数为 5，整体上限 $c = 2$ 给出 $(1.2, 1.6)^\top$ ；逐元素上限 2 则给出 $(2, 2)^\top$ ，方向已改变。裁剪用于控制极端更新，不是对小梯度统一放大，也不能恢复已经消失的历史梯度。若训练中几乎每一步都被大幅裁剪，还应检查损失缩放、初始化或状态递推，而不是只继续降低上限。

14.2.4 动量法

第14.1.2节中，陡方向的梯度来回变号，缓方向却持续指向谷底。只读取当前梯度，不能利用这种持续性区别。**动量法**（momentum）将历史梯度积累为更新方向，使往返分量部分抵消、同向分量持续推进；它也能平滑部分抽样波动。采用未归一化的累积约定，令

$$\mathbf{m}^{(t)} = \beta \mathbf{m}^{(t-1)} + \mathbf{g}^{(t)}, \quad \boldsymbol{\theta}^{(t)} = \boldsymbol{\theta}^{(t-1)} - \eta_t \mathbf{m}^{(t)}, \quad \beta \in [0, 1]. \quad (14.11)$$

交替的梯度会部分抵消，持续同向的梯度会积累。如果 $\mathbf{g}^{(t)}$ 近似恒定，累积量趋向 $\mathbf{g}/(1 - \beta)$ ，因此调整 β 也改变有效更新尺度。另一约定在梯度前乘 $1 - \beta$ ；比较实现时要同时对应学习率。

动量怎样改变曲率方向上的传播，可以在二次目标中看清。沿特征值为 λ 的方向，固定 η, β 时的误差满足

$$e^{(t)} = (1 - \eta\lambda + \beta)e^{(t-1)} - \beta e^{(t-2)}. \quad (14.12)$$

它从单步收缩变为二阶递推，收敛取决于两个特征根，而不只取决于 $1 - \eta\lambda$ 。对曲率介于 $\lambda_{\min} > 0$ 与 $\lambda_{\max}$ 之间的精确二次目标，取 $\eta = 4/(\sqrt{\lambda_{\max}} + \sqrt{\lambda_{\min}})^2$ 、 $\beta = [(\sqrt{\kappa} - 1)/(\sqrt{\kappa} + 1)]^2$ ，特征根的最大模为 $(\sqrt{\kappa} - 1)/(\sqrt{\kappa} + 1)$ 。这是该二次模型的渐近速率，重根时还可能带多项式因子，不能当成任意网络的逐步损失界。

动量只增加一个 p 维缓冲，但也使更新具有惯性。梯度突然换方向时，旧方向不会立即消失；较大的 β 提供更长历史，也可能让响应迟缓。它对噪声的平滑和对有效步长的放大应一起考虑。

14.2.5 Nesterov 加速方法

动量保存旧方向，也可能在接近谷底时继续推动参数。Nesterov 方法让梯度读取历史方向预计到达的位置，以修正这种惯性。**Nesterov 加速方法** (Nesterov accelerated gradient, NAG) 在历史方向指向的前瞻位置计算梯度，而不是只对当前位置的梯度做累积。对式(14.11)的约定，可写为

$$\bar{\theta}^{(t)} = \theta^{(t-1)} - \eta_t \beta \mathbf{m}^{(t-1)}, \quad (14.13)$$

$$\mathbf{m}^{(t)} = \beta \mathbf{m}^{(t-1)} + \nabla \mathcal{L}(\bar{\theta}^{(t)}), \quad \theta^{(t)} = \theta^{(t-1)} - \eta_t \mathbf{m}^{(t)}. \quad (14.14)$$

前瞻梯度提供对惯性方向的修正。深度学习实现常采用等价变换或固定动量的变体；经典凸优化中的加速率依赖目标条件和系数选择，不能直接赋予任意非凸随机训练过程。

以一维 $q(\theta) = a\theta^2/2$ 为例，普通动量读取 $a\theta$ ，前瞻形式读取 $a(\theta - \eta\beta m)$ 。若惯性正将参数推向谷底，前瞻梯度已看到较低位置，从而减少继续沿旧方向推进的量；若已越过谷底，则可能更早得到相反方向的修正。这个例子解释了机制，不意味着每次前瞻都改善损失。

式(14.14)直接展示“到前瞻位置求导”的定义。实际实现也可把参数位置作等价重写，以避免额外前向计算；变动学习率或动量时，等价关系需要重新对应。判断两个名为 NAG 的实现是否一致，要检查求导位置、缓冲约定和最终更新式。

前瞻的优势是让惯性修正在本步方向形成前发生，在相应凸条件下可得到加速结论。它仍保留动量的历史滞后，也会受到前瞻位置梯度噪声的影响；非凸网络中前瞻点可能落入与当前位置不同的局部形状。因而它提供另一种方向构造，不能仅凭“加速”名称省去步长和动量的调节。

14.2.6 AdaGrad

有些参数经常收到大梯度，有些只在少数样本出现时更新，同一全局步长无法分别照顾两者。**自适应学习率** (adaptive learning rate) 用历史梯度统计量为不同坐标设置相对尺度。逐坐标统计比完整矩阵便宜，但不完整描述第14.1.2节中的方向耦合；它适应的是观测梯度的大小和出现频率，不必等价于真实局部曲率。

AdaGrad 累计逐坐标平方梯度。令 $\mathbf{v}^{(0)} = \mathbf{0}$ ，其常见对角形式为

$$\mathbf{v}^{(t)} = \mathbf{v}^{(t-1)} + \mathbf{g}^{(t)} \odot \mathbf{g}^{(t)}, \quad \theta^{(t)} = \theta^{(t-1)} - \eta \frac{\mathbf{g}^{(t)}}{\sqrt{\mathbf{v}^{(t)}} + \epsilon}. \quad (14.15)$$

$\odot$ 为逐元素乘法， $\epsilon > 0$ 防止分母为 0。反复收到大梯度的坐标逐渐减小更新尺度，较少更新的坐标则保留较大相对尺度。累积量不减小，长期训练

中步长可能变得过小³。

若某个坐标每步收到相同的非零梯度 $\mathbf{g}$ ，忽略 ϵ 时，第 t 步的更新幅度为 $\eta/\sqrt{t}$ ；梯度的绝对尺度被平方累积抵消。一个很少出现的特征则只在出现时增加该坐标累积量，因此按访问次数减小步长。这是 AdaGrad 适合分析稀疏梯度的原因，但不能据此保证在任何稀疏网络上都优于其他方法。

AdaGrad 增加一个 p 维累积量，每步的逐元素处理为 $O(p)$ 。累计统计无法主动忘记训练早期的大梯度：目标分布或训练阶段改变后，早期尺度仍会限制当前更新。RMSProp 接下来用有限记忆缓解这一点。

14.2.7 RMSProp

AdaGrad 的累计历史不遗忘，早期大梯度可能长期压低后续步长。若训练阶段的尺度改变，指数平均可以让近期梯度重新决定分母。RMSProp 改用近期平方梯度的指数移动平均： $\mathbf{v}^{(t)} = \rho \mathbf{v}^{(t-1)} + (1 - \rho) \mathbf{g}^{(t)} \odot \mathbf{g}^{(t)}$ ，再用式(14.15)中的分母更新， $\rho \in [0, 1)$ 。旧梯度影响衰减，因此相对尺度可以随着训练阶段改变。其平方平均、开方和稳定项的位置应以具体实现为准⁴。

为明确它与 AdaGrad 的不同，把更新完整写为

$$\begin{aligned}\mathbf{v}^{(t)} &= \rho \mathbf{v}^{(t-1)} + (1 - \rho) \mathbf{g}^{(t)} \odot \mathbf{g}^{(t)}, \\ \boldsymbol{\theta}^{(t)} &= \boldsymbol{\theta}^{(t-1)} - \eta_t \mathbf{g}^{(t)} / (\sqrt{\mathbf{v}^{(t)}} + \epsilon).\end{aligned}\tag{14.16}$$

过去第 s 步平方梯度在第 t 步的权重为 $(1 - \rho)\rho^{t-s}$ 。较大的 ρ 使尺度变化更平缓，却更慢适应新梯度；较小的 ρ 响应更快，也增加分母波动。零初值下的恒定梯度给出 $\mathbf{v}^{(t)} = (1 - \rho^t)\mathbf{g}^2$ ，因此早期分母尚未达到稳态，初始更新可能比稳态更大。

基本 RMSProp 使用一个 p 维二阶矩状态，可另外组合动量。它观察的是当前坐标的历史平方梯度，对坐标旋转通常不具有不变性，也不利用坐标之间的耦合。不能把“自适应”理解为无需学习率或自动消除病态曲率。

14.2.8 AdaDelta

只根据平方梯度设置分母，仍需选择参数实际移动的尺度。AdaDelta 把近期更新也纳入统计，用更新与梯度的两类均方根之比调节幅度，减少对单一固定全局尺度的依赖。设 $\mathbf{v}^{(t)}$ 为上述平方梯度平均， $\mathbf{r}^{(t)}$ 为平方更新平

³ J. Duchi, E. Hazan, Y. Singer, *Adaptive Subgradient Methods for Online Learning and Stochastic Optimization* In *Journal of Machine Learning Research*, 2011, vol. 12, no. 61, pp. 2121–2159

⁴ G. Hinton, *Neural Networks for Machine Learning: Lecture 6*, University of Toronto, 2012, URL: https://www.cs.toronto.edu/~tijmen/csc321/slides/lecture_slides_lec6.pdf (visited on 10/04/2026)

均, 则原始基本形式为

$$\Delta\theta^{(t)} = -\frac{\sqrt{\mathbf{r}^{(t-1)} + \epsilon}}{\sqrt{\mathbf{v}^{(t)} + \epsilon}} \odot \mathbf{g}^{(t)}, \quad (14.17)$$

$$\mathbf{r}^{(t)} = \rho\mathbf{r}^{(t-1)} + (1 - \rho)\Delta\theta^{(t)} \odot \Delta\theta^{(t)}, \quad (14.18)$$

$$\theta^{(t)} = \theta^{(t-1)} + \Delta\theta^{(t)}. \quad (14.19)$$

分子使用前一步统计量, 避免与本步更新形成循环定义。这个基本形式没有独立的全局学习率, 但仍需选择 ρ 、稳定项和初值; 有些实现还允许乘以全局系数, 不能据此认为算法无需调节⁵。

如果某个坐标近期更新很小, 分子会减小该坐标的更新; 梯度尺度上升时, 分母则抑制幅度。分子与分母共同把近期参数变化和近期梯度联系起来, 这是它区别于仅累计梯度平方的方法之处。两个状态均按坐标保存, 额外存储为 $O(p)$, 但常数是两组统计量。

稳定项同时承担零初值启动的作用。如果 $\mathbf{r}^{(0)} = \mathbf{0}$ 且完全去掉 ϵ , 第一步分子就为 0; 算法不能靠尚未发生的更新自行启动。实际 ϵ 的数值与单位、 ρ 及全局缩放约定都会影响轨迹。

⁵ M. D. Zeiler, *ADADELTA: An Adaptive Learning Rate Method* In arXiv preprint arXiv:1212.5701, 2012

14.2.9 Adam 与 AMSGrad

抽样噪声影响方向, 坐标尺度差异影响幅度; 单独的动量或平方统计各处理一部分。Adam 同时维护梯度的一阶矩和非中心化二阶矩, 前者给平滑方向, 后者给逐坐标尺度, 以较低的逐元素计算成本组合两种处理。AMSGrad 进一步管理分母随时间变化的问题。以零初值定义

$$\mathbf{m}^{(t)} = \beta_1\mathbf{m}^{(t-1)} + (1 - \beta_1)\mathbf{g}^{(t)}, \quad (14.20)$$

$$\mathbf{v}^{(t)} = \beta_2\mathbf{v}^{(t-1)} + (1 - \beta_2)\mathbf{g}^{(t)} \odot \mathbf{g}^{(t)}, \quad (14.21)$$

$$\hat{\mathbf{m}}^{(t)} = \frac{\mathbf{m}^{(t)}}{1 - \beta_1^t}, \quad \hat{\mathbf{v}}^{(t)} = \frac{\mathbf{v}^{(t)}}{1 - \beta_2^t}, \quad (14.22)$$

$$\theta^{(t)} = \theta^{(t-1)} - \eta_t \frac{\hat{\mathbf{m}}^{(t)}}{\sqrt{\hat{\mathbf{v}}^{(t)} + \epsilon}}. \quad (14.23)$$

$\beta_1, \beta_2 \in [0, 1)$ 为平滑系数。分母中的修正因子来自零初值: 把 $\mathbf{m}^{(0)} = \mathbf{0}$ 代入递推, 假设第 1 至 t 步梯度具有相同的有限均值 $\mathbb{E}[\mathbf{g}^{(s)}] = \boldsymbol{\mu}$, 就有

$$\begin{aligned} \mathbf{m}^{(t)} &= (1 - \beta_1) \sum_{s=1}^t \beta_1^{t-s} \mathbf{g}^{(s)}, \\ \mathbb{E}[\mathbf{m}^{(t)}] &= (1 - \beta_1) \sum_{s=1}^t \beta_1^{t-s} \boldsymbol{\mu} = (1 - \beta_1^t) \boldsymbol{\mu}. \end{aligned} \quad (14.24)$$

第二行只用期望的线性性质与等比求和，不要求各步梯度相互独立。有限步的权重和是 $1 - \beta_1^t$ ，尚未达到 1；除以它，便在上述同均值假设下得到 $\mathbb{E}[\hat{\mathbf{m}}^{(t)}] = \boldsymbol{\mu}$ 。同理，若各步的逐坐标非中心二阶矩均为 $\boldsymbol{\nu} = \mathbb{E}[\mathbf{g}^{(s)} \odot \mathbf{g}^{(s)}]$ 且有限，零初值 $\mathbf{v}^{(0)} = \mathbf{0}$ 给出 $\mathbb{E}[\mathbf{v}^{(t)}] = (1 - \beta_2^t)\boldsymbol{\nu}$ 。这里没有减去梯度均值， $\boldsymbol{\nu}$ 不是梯度方差。偏差修正消除的是零初始化的权重缺口；实际梯度统计随参数变化，它既不消除抽样偏差，也不使历史平均等同于当前精确矩⁶。

这里的二阶矩是 $\mathbf{g}_j^2$ 的平均，Hessian 是损失对参数的二阶导数。前者即使在负曲率区域也非负，且包含梯度均值和噪声方差；后者可以有负特征值。Adam 属于用一阶梯度统计构造更新的方法。它仍需全局学习率和调度，在不同问题上也不能无条件保证比经过调节的 SGD 更快或泛化更好。

Adam 的第一次更新很有辨识度：零初值下，偏差修正后 $\hat{\mathbf{m}}^{(1)} = \mathbf{g}^{(1)}$ 、 $\hat{\mathbf{v}}^{(1)} = (\mathbf{g}^{(1)})^2$ ，所以忽略 ϵ 时，非零坐标按 $-\eta_1 \text{sign}(\mathbf{g}^{(1)})$ 移动。后续步则由历史方向与历史尺度共同决定，不能把 Adam 始终写成符号下降。两组 p 维状态增加存储，恢复训练时也必须恢复它们。

Adam 的指数平均可能降低分母，使某个坐标的有效步长重新增大。AMSGrad 用历史最大二阶矩阻止这种下降。省略初始化偏差修正时，可写为

$$\hat{\mathbf{v}}^{(t)} = \max(\hat{\mathbf{v}}^{(t-1)}, \mathbf{v}^{(t)}), \quad \boldsymbol{\theta}^{(t)} = \boldsymbol{\theta}^{(t-1)} - \eta_t \mathbf{m}^{(t)} / (\sqrt{\hat{\mathbf{v}}^{(t)}} + \epsilon), \quad (14.25)$$

最大值逐元素计算， $\hat{\mathbf{v}}^{(0)} = \mathbf{0}$ 。加入偏差修正的实现还需对应其具体约定。AMSGrad 针对 Adam 的某些收敛问题提出，但其条件性分析不意味着在所有神经网络上都有更高任务精度；历史最大值也减少了对后期较小梯度尺度的适应⁷。

图 14.3 把 SGD、动量和 Adam 放到同一个病态二次目标上逐步计算。SGD 在陡方向反复越过谷底，缓方向只按固定比例缩小；动量利用历史方向加快沿谷底推进，但仍带有惯性振荡；Adam 在这个轴对齐例子中按坐标缩放，前几步几乎沿对角线接近原点。三条轨迹使用各自给定的超参数，只用于辨认更新机制，不构成跨任务的优劣排名。

AdamW 将权重衰减与矩统计分开，公式及其与 L2 惩罚的区别见第 15.4.5 节。优化方向、步长统计与参数收缩是可以分别选择的三个设计对象。

14.2.10 Adafactor 与低存储二阶矩估计

逐坐标尺度处理虽然便宜于完整曲率矩阵，在大模型中保存一张与参数同大的统计表仍可能昂贵。Adafactor 通过保留行列边际，在历史存储与细节尺度之间取舍。Adafactor 利用矩阵的行、列统计近似逐元素二阶矩，并可省去完整动量状态。这里近似的是平方梯度表，不是 Hessian，也不是

⁶ D. P. Kingma, J. Ba, *Adam: A Method for Stochastic Optimization* In International Conference on Learning Representations, 2015

⁷ S. J. Reddi, S. Kale, S. Kumar, *On the Convergence of Adam and Beyond* In International Conference on Learning Representations, 2018




图 14.3 SGD、动量与 Adam 在同一病态二次目标上的前 20 步。目标为 $q(\theta) = (25\theta_1^2 + \theta_2^2)/2$ ，条件数 $\kappa = 25$ ，三者均从 $(1, 1)^T$ 出发并使用完整梯度；灰线为等高线，黄色点为唯一极小点。轨迹由正文定义的递推式直接计算，图例列出步长和矩系数。不同超参数会改变速度与振荡，不能据此推出某方法对一般非凸随机训练恒优。

左右矩阵预条件。

设矩阵参数为 $\mathbf{W} \in \mathbb{R}^{m \times d}$ ，梯度为 $\mathbf{D}^{(t)}$ ，取 $A_{i,j}^{(t)} = (D_{i,j}^{(t)})^2 + \epsilon_1$ ， $\epsilon_1 > 0$ 。令 $r_i^{(t)}$ 和 $c_j^{(t)}$ 分别为行均值与列均值的指数平均，一个简化形式为

$$r_i^{(t)} = \beta_t r_i^{(t-1)} + (1 - \beta_t) \frac{1}{d} \sum_j A_{i,j}^{(t)}, \quad (14.26)$$

$$c_j^{(t)} = \beta_t c_j^{(t-1)} + (1 - \beta_t) \frac{1}{m} \sum_i A_{i,j}^{(t)}, \quad (14.27)$$

$$\hat{V}_{i,j}^{(t)} = \frac{r_i^{(t)} c_j^{(t)}}{m^{-1} \sum_k r_k^{(t)}}. \quad (14.28)$$

两组均值从 0 以同一 $\beta_t \in [0, 1)$ 更新，其整体均值一致。重构表保留行、列边际，却不能保存任意单元元素变化；某个格子的独特统计会被这种秩一结构近似。

得到 $\mathbf{U} = \mathbf{D}/\sqrt{\hat{\mathbf{V}}}$ 后，原始方法还裁剪更新的均方根，并按参数尺度设置相对步长。记 $\text{rms}(\mathbf{A}) = \sqrt{(md)^{-1} \sum_{i,j} A_{i,j}^2}$ ，可以写为

$$\Delta = -\rho_t \max(\epsilon_2, \text{rms}(\mathbf{W})) \frac{\mathbf{U}}{\max(1, \text{rms}(\mathbf{U})/c)}, \quad (14.29)$$

其中 ρ_t 为相对步长， $c > 0$ 为更新上限， $\epsilon_2 > 0$ 控制近零参数的尺度。这里裁剪的是预条件后的更新，不同于前面裁剪原始梯度。统计衰减、相对

步长与可选动量均需按具体实现指定⁸。

不使用完整动量时，这个矩阵块的历史状态从 $O(md)$ 降为 $O(m+d)$ ，但梯度与临时更新仍有 md 个元素，不能把整个训练存储也说成线性于 $m+d$ 。向量参数通常不能按同样方式分解，仍需逐元素统计。

14.2.11 Lion 与符号动量更新

历史方向的作用未必要求同时保存平方统计。Lion 尝试只保留动量，以符号方向换取较少状态；代价是放弃梯度混合量的绝对幅度。Lion 保留一组动量，用历史与当前梯度的混合决定各坐标的符号。取零初值，一个带解耦衰减的基本形式为

$$\mathbf{z}^{(t)} = \beta_1 \mathbf{m}^{(t-1)} + (1 - \beta_1) \mathbf{g}^{(t)}, \quad (14.30)$$

$$\boldsymbol{\theta}^{(t)} = (1 - \eta_t \lambda) \boldsymbol{\theta}^{(t-1)} - \eta_t \text{sign}(\mathbf{z}^{(t)}), \quad (14.31)$$

$$\mathbf{m}^{(t)} = \beta_2 \mathbf{m}^{(t-1)} + (1 - \beta_2) \mathbf{g}^{(t)}. \quad (14.32)$$

两种平滑系数分别控制本步方向和留给后续的状态，均在 $[0, 1]$ 内， $\lambda \geq 0$ 为衰减系数。更新使用旧动量，随后再保存新动量；把次序交换会改变算法⁹。

符号操作让非零坐标的基础更新幅度相同，放弃了混合梯度的绝对大小。如果有 q 个非零符号，未计衰减时的更新范数就是 $\eta_t \sqrt{q}$ ，这说明与 Adam 相同的学习率数值未必对应相同总步长。它增加一组 p 维状态，存储常数较小，但不能恢复被符号量化去掉的幅度信息。

14.2.12 牛顿法、阻尼与步长控制

第14.1.2节中的主曲率方向未必与坐标轴对齐，逐坐标缩放因而可能保留严重的方向差异。二阶局部模型用 Hessian 描述耦合，让更新沿曲率方向分别调整幅度。对当前参数附近的小变化 Δ ，二次近似为

$$\mathcal{L}(\boldsymbol{\theta} + \Delta) \approx \mathcal{L}(\boldsymbol{\theta}) + \mathbf{g}^\top \Delta + \frac{1}{2} \Delta^\top \mathbf{H} \Delta. \quad (14.33)$$

牛顿法 (Newton's method) 在 $\mathbf{H}$ 正定时取 $\Delta = -\mathbf{H}^{-1} \mathbf{g}$ ，也就是求解线性系统 $\mathbf{H} \Delta = -\mathbf{g}$ 。对精确正定二次函数，一步到达极小点；一般非线性目标的近似只在局部可靠。Hessian 不正定时，该方向未必下降，求解二次模型还可能没有最小值。

阻尼 (damping) 用 $\mathbf{H} + \lambda \mathbf{I}$ 调整曲率， $\lambda > 0$ 足够大时可使其正定。**线搜索** (line search) 在已有方向上试验多个步长，用实际目标检查下降；**信赖域** (trust region) 则限制 $\|\Delta\|_2 \leq r$ ，只在局部模型可信的范围内寻找更新，并依据预测下降与实际下降的吻合程度调节 r 。三种思路分别控制曲

⁸ N. Shazeer, M. Stern, *Adafactor: Adaptive Learning Rates with Sub-linear Memory Cost* In Proceedings of the 35th International Conference on Machine Learning, 2018, pp. 4596–4604

⁹ X. Chen, C. Liang, D. Huang, E. Real, K. Wang, Y. Liu, H. Pham, X. Dong, T. Luong, C.-J. Hsieh, Y. Lu, Q. V. Le, *Symbolic Discovery of Optimization Algorithms* In Advances in Neural Information Processing Systems 36, 2023

率、沿方向的距离和模型使用范围，可以组合。

曲率修正的优势是直接处理耦合与尺度差异，在良好局部条件下比单一全局步长更快。代价是曲率计算和线性求解：显式矩阵需 $O(p^2)$ 存储，一般稠密求解约为 $O(p^3)$ 。局部模型不准确、Hessian 接近奇异或小批量估计波动时，方向可能被过度放大；阻尼改善稳定性，也会削弱曲率修正。负曲率还应区别于数值错误，强行使矩阵正定会舍去这一逃离鞍点的信息。

14.2.13 BFGS 与 L-BFGS

牛顿法每次计算完整曲率的成本较高。若相邻迭代的梯度差能够反映参数移动造成的变化，就可以用这些差量近似曲率作用，减少直接求二阶导数的需求。**拟牛顿方法** (quasi-Newton methods) 不逐次计算完整 Hessian，而利用相邻参数和梯度变化构造近似。令 $\mathbf{s}^{(t)} = \boldsymbol{\theta}^{(t)} - \boldsymbol{\theta}^{(t-1)}$, $\mathbf{y}^{(t)} = \nabla \mathcal{L}(\boldsymbol{\theta}^{(t)}) - \nabla \mathcal{L}(\boldsymbol{\theta}^{(t-1)})$ ，逆曲率近似 $\mathbf{B}$ 应满足割线关系 $\mathbf{B}\mathbf{y} = \mathbf{s}$ 。BFGS 采用

$$\begin{aligned} \mathbf{B}_{\text{new}} &= (\mathbf{I} - \rho \mathbf{s} \mathbf{y}^\top) \mathbf{B} (\mathbf{I} - \rho \mathbf{y} \mathbf{s}^\top) + \rho \mathbf{s} \mathbf{s}^\top, \\ \rho &= 1/(\mathbf{y}^\top \mathbf{s}). \end{aligned} \quad (14.34)$$

若 $\mathbf{B}$ 正定且 $\mathbf{y}^\top \mathbf{s} > 0$ ，更新保留正定性。后者不满足时需跳过、阻尼或另外处理，不能直接除以任意内积。L-BFGS 只保存最近 k 组 $(\mathbf{s}, \mathbf{y})$ ，通过两轮递推计算 $\mathbf{B}\mathbf{g}$ ，存储从 $O(p^2)$ 降到 $O(kp)$ 。

小批量噪声可能让梯度差主要反映样本变化，而非参数变化，导致曲率估计失真。拟牛顿方法因此需要关注梯度差的数据一致性、批量和阻尼。完整矩阵的存储和线性求解仍是大网络使用二阶信息的主要约束¹⁰。

L-BFGS 不需要先恢复 $\mathbf{B}$ 的全部元素。算法 14.1 给出两轮递推：先从最新变化向过去消去 $\mathbf{y}_j$ 方向，再从过去到现在补回 $\mathbf{s}_j$ 方向。每组历史都需要 $\mathbf{y}_j^\top \mathbf{s}_j > 0$ ；不满足时应在收集阶段处理。

¹⁰ L. Bottou, F. E. Curtis, J. Nocedal, *Optimization Methods for Large-Scale Machine Learning* In SIAM Review, 2018, vol. 60, no. 2, pp. 223–311

算法 14.1 L-BFGS 两轮递推

输入： 当前梯度 $\mathbf{g}$ ，按时间排序的 k 组 $(\mathbf{s}_j, \mathbf{y}_j)$ ，正定初始近似 $\mathbf{B}_0$

输出： 逆曲率作用后的方向 $\mathbf{r}$ ，参数沿 $-\mathbf{r}$ 更新

```

1:  $\mathbf{q} \leftarrow \mathbf{g}$ ,  $\rho_j \leftarrow 1/(\mathbf{y}_j^\top \mathbf{s}_j)$ 
2: for  $j = k, \dots, 1$  do
3:    $\mathbf{a}_j \leftarrow \rho_j \mathbf{s}_j^\top \mathbf{q}$ 
4:    $\mathbf{q} \leftarrow \mathbf{q} - \mathbf{a}_j \mathbf{y}_j$ 
5: end for
6:  $\mathbf{r} \leftarrow \mathbf{B}_0 \mathbf{q}$ 
7: for  $j = 1, \dots, k$  do
8:    $\mathbf{b}_j \leftarrow \rho_j \mathbf{y}_j^\top \mathbf{r}$ 
9:    $\mathbf{r} \leftarrow \mathbf{r} + \mathbf{s}_j (\mathbf{a}_j - \mathbf{b}_j)$ 
10: end for
```

常见 $B_0 = \gamma I$ ，尺度可取最近一组的 $\gamma = (\mathbf{s}_k^\top \mathbf{y}_k) / (\mathbf{y}_k^\top \mathbf{y}_k) > 0$ 。两轮递推每步约 $O(kp)$ ，仍要另行确定步长；线搜索可能增加多次目标和梯度评估。这个开销与一个只做逐元素运算的优化器不同。

14.2.14 广义 Gauss-Newton 方法

第14.1.1节说明了非凸 Hessian 可以包含负方向，直接求解未必得到下降步。GGN 舍去网络输出非线性带来的一部分曲率，保留输出损失中更易控制的部分。令单样本网络输出为 $\mathbf{z}_i = f_\theta(\mathbf{x}_i) \in \mathbb{R}^c$ ，输出雅可比为 $\mathbf{J}_i \in \mathbb{R}^{c \times p}$ ，单样本损失为 $\ell_i = \ell(\mathbf{z}_i, \mathbf{y}_i)$ 。复合损失的 Hessian 可以分为

$$\mathbf{H} = \frac{1}{n} \sum_i \left[\mathbf{J}_i^\top \nabla_{\mathbf{z}_i}^2 \ell_i \mathbf{J}_i + \sum_{k=1}^c \frac{\partial \ell_i}{\partial z_{i,k}} \nabla_{\theta}^2 z_{i,k} \right]. \quad (14.35)$$

第一项来自损失对输出的曲率，第二项来自网络输出对参数的非线性。**广义 Gauss-Newton 矩阵** (generalized Gauss-Newton matrix, GGN) 只保留第一项，记为 $\mathbf{G}$ 。若损失对输出凸， $\mathbf{G}$ 半正定；加阻尼后可用于构造下降方向，但它省略了真实 Hessian 的部分信息。

平方损失 $\ell_i = \|\mathbf{z}_i - \mathbf{y}_i\|_2^2/2$ 对输出的 Hessian 是单位矩阵，于是 $\mathbf{G} = n^{-1} \sum_i \mathbf{J}_i^\top \mathbf{J}_i$ 。输出对参数线性时，分解中的第二项为 0，GGN 等于真实 Hessian；非线性网络中若残差接近 0，第二项可能较小，但必须检查输出二阶导数与残差的乘积，不能只凭“训练误差低”就宣称完全相等。

在当前点，把输出局部近似为 $\mathbf{z}_i + \mathbf{J}_i \Delta$ ，再保留损失的输出曲率，就能得到这种二次模型。它放弃部分非凸曲率，换来更容易控制的半正定矩阵；阻尼决定对低曲率方向放大多少，而求解精度决定是否接近该模型的最优更新。

14.2.15 自然梯度与 Fisher 度量

病态曲率也提醒我们，参数坐标中的相同距离未必对应相同的预测变化。自然梯度改用输出分布变化衡量步长，从函数行为而非裸参数长度构造局部方向。如果网络定义条件概率 $p_\theta(\mathbf{y} | \mathbf{x})$ ，还可以按输出分布变化的大小衡量参数步长。**Fisher 信息矩阵** (Fisher information matrix) 在这里为

$$\mathbf{F} = \mathbb{E}_{\mathbf{x}} \mathbb{E}_{\mathbf{y} \sim p_\theta(\cdot | \mathbf{x})} [\mathbf{a} \mathbf{a}^\top], \quad \mathbf{a} = \nabla_{\theta} \log p_\theta(\mathbf{y} | \mathbf{x}). \quad (14.36)$$

在满足常规可微条件时，邻近参数的平均 KL 散度二阶项为 $\frac{1}{2} \Delta^\top \mathbf{F} \Delta$ 。**自然梯度** (natural gradient) 按这一分布度量构造下降方向，基本形式为 $-(\mathbf{F} + \lambda \mathbf{I})^{-1} \mathbf{g}$ 。理想的无阻尼度量具有重参数化不变性，实际阻尼和近似会改变该性质¹¹。

¹¹ J. Martens, *New Insights and Perspectives on the Natural Gradient Method* In Journal of Machine Learning Research, 2020, vol. 21, no. 146, pp. 1–76

这个方向可从一个局部约束问题推出：在 $\Delta^\top \mathbf{F} \Delta / 2 \leq \delta$ 内最小化 $\mathbf{g}^\top \Delta$ 。若 $\mathbf{F}$ 正定且梯度非零，拉格朗日条件给出 $\Delta = -c \mathbf{F}^{-1} \mathbf{g}$ ，再由约束确定 $c = \sqrt{2\delta / (\mathbf{g}^\top \mathbf{F}^{-1} \mathbf{g})}$ 。因此，自然梯度按“输出分布改变多少”分配方向，而普通梯度按当前参数坐标的欧氏长度分配方向。

对负对数似然、以自然参数表示的指数族输出，合适定义下的 GGN 与模型 Fisher 可以相等。用训练标签的梯度外积直接平均得到的**经验 Fisher** (empirical Fisher) 却通常不同，因为标签来自数据，而非当前模型分布。Hessian、GGN、模型 Fisher 和经验 Fisher 描述的对象不同，只有给定输出模型与期望口径后才能讨论等价关系。

使用这些矩阵也不必显式生成全部 p^2 个元素。对向量 $\mathbf{v}$ ，可以计算 $\mathbf{J}_i \mathbf{v}$ ，再经输出损失曲率和 $\mathbf{J}_i^\top$ 回传，得到 $\mathbf{G} \mathbf{v}$ ；Hessian-向量乘积也可由自动微分实现。对正定的阻尼系统，用共轭梯度等迭代方法近似求解。每次迭代增加计算，停止容差、数据批量和矩阵近似共同决定更新质量。

14.2.16 K-FAC

若希望利用层内方向关系，又无法保存全部参数间的矩阵，网络层的输入与输出维度便提供了可利用的分解结构。K-FAC 把这一结构用于 Fisher 近似，降低自然梯度的矩阵处理成本。完整矩阵同时保存所有参数间关系，代价随 p^2 增长。结构化方法只保存一部分：对角近似保留逐坐标尺度，分块近似保留块内关系，低秩近似保留少数主要方向，Kronecker 分解则利用参数张量的输入和输出维度分离计算。近似方式决定哪些耦合被保留，也决定额外成本。

K-FAC 以网络层结构近似 Fisher。考虑 $\mathbf{W} \in \mathbb{R}^{m \times d}$ 的线性层，输入为 $\mathbf{a} \in \mathbb{R}^d$ ，负对数似然对层输出的梯度为 $\boldsymbol{\delta} \in \mathbb{R}^m$ ，单样本权重梯度为 $\boldsymbol{\delta} \mathbf{a}^\top$ 。按列展平后，其外积对应 $(\mathbf{a} \mathbf{a}^\top) \otimes (\boldsymbol{\delta} \boldsymbol{\delta}^\top)$ ， $\otimes$ 为 Kronecker 积。K-FAC 将联合期望近似为

$$\mathbf{F}_{\text{layer}} \approx \mathbf{A} \otimes \mathbf{S}, \quad \mathbf{A} = \mathbb{E}[\mathbf{a} \mathbf{a}^\top], \quad \mathbf{S} = \mathbb{E}[\boldsymbol{\delta} \boldsymbol{\delta}^\top]. \quad (14.37)$$

忽略其他块和阻尼细节时，矩阵梯度 $\mathbf{D}$ 对应更新 $-\eta \mathbf{S}^{-1} \mathbf{D} \mathbf{A}^{-1}$ 。这个因子化通常是近似，不是一般性的独立结论； $\boldsymbol{\delta}$ 的采样方式也决定所近似的是模型 Fisher 还是其他统计量。两因子的存储为 $O(d^2 + m^2)$ ，分别求逆比处理 $(md) \times (md)$ 矩阵便宜。实际算法还需阻尼、统计更新频率及层间近似¹²。

K-FAC 的优势是以层结构保留比对角方法更多的方向关系，同时避免完整 Fisher。其局限也来自这一结构：因子化舍去输入与输出梯度的部分联合关系，分块舍去部分跨层耦合；大输入或输出维度下，两张因子矩阵仍可能很大。降低统计和求逆频率可以节省计算，却会使预条件滞后于当

¹² J. Martens, R. Grosse, *Optimizing Neural Networks with Kronecker-Factored Approximate Curvature* In Proceedings of the 32nd International Conference on Machine Learning, 2015, pp. 2408–2417

前网络。

14.2.17 Shampoo

逐坐标分母不保留行列方向的相关性,完整预条件又过于昂贵。Shampoo 以参数张量的维度为单位保存梯度关系,提供两者之间的一种选择。Shampoo 同样沿张量维度构造矩阵,但信息来源是历史梯度的 Gram 统计,而不是上面的激活与输出分布度量。对矩阵梯度 $\mathbf{D}^{(t)} \in \mathbb{R}^{m \times d}$, 一个基本版本为

$$\mathbf{L}^{(t)} = \epsilon \mathbf{I}_m + \sum_{s=1}^t \mathbf{D}^{(s)} (\mathbf{D}^{(s)})^\top, \quad (14.38)$$

$$\mathbf{R}^{(t)} = \epsilon \mathbf{I}_d + \sum_{s=1}^t (\mathbf{D}^{(s)})^\top \mathbf{D}^{(s)}, \quad (14.39)$$

$$\mathbf{W}^{(t)} = \mathbf{W}^{(t-1)} - \eta_t (\mathbf{L}^{(t)})^{-1/4} \mathbf{D}^{(t)} (\mathbf{R}^{(t)})^{-1/4}. \quad (14.40)$$

这里 $\epsilon > 0$, 负四分之一次幂是对正定矩阵的特征值作相应变换。左右预条件分别调整行、列方向,并可推广到高阶张量。存储同样是 $O(m^2 + d^2)$, 还需 Gram 矩阵计算和矩阵根; 分块和降低根计算频率能控制开销, 也会改变近似。Shampoo 属于梯度统计驱动的预条件, 不应自动称为 Hessian 近似¹³。

与逐元素分母相比, 它能沿行列子空间调整相关方向, 且只需梯度而不要求概率输出。它仍没有保留所有展平参数间的关系, 累计统计也可能滞后于后期尺度。矩阵根的近似、稳定项和分块大小决定了这种额外方向信息是否抵得上计算成本。

14.2.18 Muon 与更新矩阵整形

当希望给矩阵更新的不同非零奇异方向赋予接近的基础尺度时, 可以直接整形更新, 而不估计损失曲率。Muon 沿这条路线改变矩阵方向的相对幅度, 再用步长决定总尺度。设某隐藏层的动量更新为 $\mathbf{M} \in \mathbb{R}^{m \times d}$, 紧致奇异值分解为 $\mathbf{M} = \mathbf{U} \mathbf{\Sigma} \mathbf{V}^\top$ 。在非零奇异值支撑上, 将更新替换为 $\mathbf{O} = \mathbf{U} \mathbf{V}^\top$, 使这些方向的奇异值接近相同尺度; 满秩矩形情形得到半正交矩阵。它不要求权重 $\mathbf{W}$ 自身正交, 且零奇异值方向不会凭空由乘法迭代恢复¹⁴。

为了理解 Newton-Schulz 迭代怎样处理更新, 先看一个可收敛的简化形式。令 $\mathbf{X}_0 = \mathbf{M} / \|\mathbf{M}\|_F$, 非零 $\mathbf{M}$ 的奇异值都不超过 1, 迭代

$$\mathbf{X}_{k+1} = \frac{3}{2} \mathbf{X}_k - \frac{1}{2} (\mathbf{X}_k \mathbf{X}_k^\top) \mathbf{X}_k. \quad (14.41)$$

若 $\mathbf{X}_k = \mathbf{U} \mathbf{\Sigma}_k \mathbf{V}^\top$, 每个奇异值按 $\sigma \mapsto (3\sigma - \sigma^3)/2$ 更新: $0 < \sigma < 1$ 时增大、仍不超过 1, 逐步趋向 1, 0 仍为 0。这就把矩阵处理化为奇异值整形。Muon 原始实现使用有限次五阶多项式 $a\mathbf{X} + b(\mathbf{X}\mathbf{X}^\top)\mathbf{X} + c(\mathbf{X}\mathbf{X}^\top)^2\mathbf{X}$, 系数

¹³ V. Gupta, T. Koren, Y. Singer, *Shampoo: Preconditioned Stochastic Tensor Optimization* In Proceedings of the 35th International Conference on Machine Learning, 2018, pp. 1842–1850

¹⁴ K. Jordan, Y. Jin, V. Boza, J. You, F. Cesista, L. Newhouse, J. Bernstein, *Muon: An Optimizer for Hidden Layers in Neural Networks*, Dec. 8, 2024, URL: <https://kellerjordan.github.io/posts/muon/> (visited on 10/04/2026)

和次数为了有限计算预算下的近似效果选择，不能套用式(14.41)的精确收敛描述。最终还需全局步长及相应的形状尺度约定。

与 Shampoo 的联系可以直接由代数看出：若不累积历史、不加稳定项，只用当前满秩方阵 $\mathbf{M}$ ，则 $(\mathbf{M}\mathbf{M}^\top)^{-1/4}\mathbf{M}(\mathbf{M}^\top\mathbf{M})^{-1/4} = \mathbf{U}\mathbf{V}^\top$ 。矩形或秩亏情况要在非零奇异子空间使用广义逆。这解释了瞬时双侧整形与极分解的联系，不能说明历史累积 Shampoo 与 Muon 具有相同训练轨迹。

对于 $m \times d$ 矩阵，选择较短维度构造 Gram 矩阵后，每次这类迭代的算术量约为 $O(md \min(m, d))$ ，另需临时存储；它用矩阵乘法避免完整奇异值分解。原始 Muon 主要处理隐藏层矩阵，向量、标量及输入输出参数另用其他优化器。这里的 Newton-Schulz 用于更新矩阵的整形，没有计算损失 Hessian，也不是直接对损失执行牛顿法。方法比较应包含达到同一训练目标的总时间与额外存储，不能只看更新次数。

14.2.19 优化方法的比较与组合

第14.1节提出的困难不是同一个问题，因此比较优化器也要比较它们使用什么信息、能控制哪个环节，而不只比较名称或单步损失。这些方法分别改变梯度历史、坐标尺度、曲率度量或矩阵更新的形状。表 14.1 比较逐坐标方法，表 14.2 比较更强耦合的方法。存储只计优化器额外状态，不计参数、当前梯度、训练激活和临时工作区。

方法	本步输入	历史状态	计算规则与输出特点
SGD	完整或抽样梯度	无同规模缓冲	沿负梯度缩放；受共同步长约束
动量 / NAG	当前 / 前瞻位置梯度	方向，一组 p 维量	累积方向；平滑与惯性并存
AdaGrad	当前梯度	累计平方，一组 p 维量	按累计尺度相除；步幅长期衰减
RMSProp	当前梯度	近期平方，一组 p 维量	按近期尺度相除；分母可能波动
AdaDelta	当前梯度	梯度与更新平方，两组 p 维量	以两种均方根之比构造增量
Adam / AMSGrad	当前梯度	两种矩及可选最大值，两组 / 三组 p 维量	平滑方向与逐坐标缩放共同作用
Adafactor	矩阵梯度	行列平方， $O(m+d)$	近似逐元素尺度，再控制块步幅
Lion	当前梯度	方向，一组 p 维量	混合后取符号；舍去幅度信息

表 14.1 从输入、状态、计算规则和输出比较常见逐坐标方法。各行均使用当前参数，步长及缩放约定见各方法正文，表中仅突出不同的梯度输入与状态；原始 AdaDelta 没有独立的全局学习率，此处 Adafactor 采用相对步长。 p 为总参数数，Adafactor 一行仅对应 $m \times d$ 矩阵块且不使用完整动量。裁剪和调度可以与这些方法组合。

方法	使用或近似的对象	代表存储	额外计算与局限
牛顿法	损失 Hessian	显式 $O(p^2)$	求解与阻尼；可用矩阵-向量乘积
BFGS / L-BFGS	参数差与梯度差	$O(p^2)$ / $O(kp)$	割线信息、线搜索及噪声敏感性
GGN	输出损失曲率与输出雅可比	显式 $O(p^2)$	可迭代求解；省略输出非线性项
自然梯度	输出概率的 Fisher 度量	显式 $O(p^2)$	模型期望、阻尼与近似
K-FAC	层内 Fisher 的 Kronecker 因子	每块 $O(m^2 + d^2)$	因子统计、求逆及层间近似
Shampoo	历史梯度的维度 Gram 矩阵	每块 $O(m^2 + d^2)$	矩阵根；不是自动的 Hessian 近似
Muon	带动量更新的奇异值形状	动量 $O(md)$	有限矩阵迭代；需临时 Gram 矩阵

表 14.2 耦合坐标或处理矩阵更新的方法。 k 为 L-BFGS 历史数； m, d 为一块矩阵的行列数。隐式求解可避免显式存储完整曲率，但会增加反复计算；表中存储不等于整个训练峰值内存。

选择方法前，应检查困难属于哪一类。梯度方向可信但幅度偶发异常时，裁剪直接控制当前信号；方向持续振荡时，动量与预条件提供不同处理；参数状态过大时，因子统计或减少状态可以节省历史存储。把这些机制组合后，还应检查最终步长、衰减作用范围和恢复训练的一致性。实际比较使用相同数据、目标与预算，报告训练损失、达到目标的时间和峰值存储，而不只记录优化器名称。

14.3 归一化方法

第14.1.2节说明坐标尺度会改变优化轨迹，第14.1.4节则说明局部导数如何沿深度累积。归一化从前向表示和参数化入手改变这些尺度与导数。输入幅度过大可能使激活饱和，通道之间尺度相差过大又可能让更新集中在少数方向。**归一化**（normalization）根据指定统计量或长度尺度调整特征或参数，必要时再加入可学习变换。它改变具体计算与参数化，也可能删去任务需要的信息。

本节按作用对象区分两部分：

- **特征归一化**。处理输入或隐藏表示，再按共同计算统计量的范围，介绍白化、批归一化、层归一化、实例归一化和组归一化。相关变体与条件扩展放在对应类别内。
- **参数归一化**。处理生成线性映射的权重，分别管理向量方向与长度、滤波器均值与方差，以及矩阵的最大放大。

混合多种统计范围、可逆仿射及图结构等不能直接归入上述常用类别的方法，在“其他归一化方法”中补充。归类以实际计算对象和范围为依据；范围相同并不意味着公式、信息保留或训练行为相同。

14.3.1 特征归一化

特征归一化改变送入后续映射的表示，也改变反向经过这些表示的导数。输入预处理通常从训练集拟合固定变换，网络内的归一化则可能在每次前

向中重新计算统计量。二者都处理特征，但参照来源和梯度依赖不同。

要判断一种归一化怎样影响训练，需把“除以尺度”展开为含统计依赖的映射。这样才能把它与第14.1.4节的局部雅可比联系起来，而不只查看输出方差。对一个统计集合 S ，常见的中心化与标准差缩放为

$$\mu_S = \frac{1}{|S|} \sum_{j \in S} x_j, \quad v_S = \frac{1}{|S|} \sum_{j \in S} (x_j - \mu_S)^2, \quad \hat{x}_j = \frac{x_j - \mu_S}{\sqrt{v_S + \epsilon}}. \quad (14.42)$$

输出通常为 $y_j = \gamma_j \hat{x}_j + \zeta_j$ 。缩放 γ_j 与偏移 ζ_j 可训练，并按指定维度共享；它们让网络选择所需输出尺度，不要求归一化后的最终输出始终均值 0、方差 1。稳定项 $\epsilon > 0$ 避免零方差除法，也控制小方差时的放大。

训练时，均值与方差通常依赖当前输入。设集合中有 d 个元素，记 $\sigma = \sqrt{v_S + \epsilon}$ 、 $\hat{\mathbf{x}} = (\mathbf{x} - \mu_S \mathbf{1})/\sigma$ ，求导得到

$$\frac{\partial \hat{\mathbf{x}}}{\partial \mathbf{x}} = \frac{1}{\sigma} \left(\mathbf{I} - \frac{\mathbf{1}\mathbf{1}^\top}{d} - \frac{\hat{\mathbf{x}}\hat{\mathbf{x}}^\top}{d} \right). \quad (14.43)$$

均值项将集合内的元素联系起来，方差项又扣除与当前中心化表示有关的方向。因此，这一步不等同于用固定常数逐元素相除。均值方向被消去；当 ϵ 可忽略时，共同缩放方向也近似被消去。若推理使用固定统计量，导数则是另一种映射。

下文将图像表示写为 $\mathbf{X} \in \mathbb{R}^{b \times c \times h \times w}$ ，分别为批量、通道、高和宽；空间位置写为 (u, v) 。选择哪些元素共同计算统计量，就确定了该归一化的作用范围。批、层、实例和组归一化的范围不同，数值结果与梯度依赖也不同；白化还要处理这些特征之间的协方差。

14.3.1.1 白化

逐特征缩放能处理量纲差异，白化进一步处理特征之间的相关性。这一类既包括在训练集上拟合并保存的输入白化，也包括在网络内重新估计协方差的白化层。先从对角尺度处理建立参照，再说明协方差变换增加了什么。

逐特征标准化与范围缩放。 量纲相差很大的输入会把尺度差异带进首层，使同一学习率难以照顾不同特征。可以先按训练数据估计每个特征的均值与标准差，再把新输入变为 $(x_j - \mu_j)/\sqrt{v_j + \epsilon}$ 。这种**输入标准化**使用保存的训练统计量，与每个小批量重新统计不同。最小-最大缩放则用训练范围映射到指定区间；单位长度归一化只改变每个向量的范数。异常值、未来范围变化和任务是否依赖绝对幅值，决定哪种变换合理。统计量的估计必须遵守训练、验证和测试边界。

输入标准化的优势是计算简单、训练推理一致，不把工作批量中的其他样本引入当前预测。它只能管理输入尺度，不能持续校正网络内部响应；

训练统计不代表未来分布时，保存的参照也会失准。

白化：从方差扩展到协方差。 第14.1.2节的困难包含方向耦合；逐特征单位方差并不会消除特征之间的相关性。白化把尺度处理扩展到协方差，使整组特征进入新的计算坐标。**白化** (whitening) 进一步用协方差矩阵变换，让中心化特征在指定统计分布下具有单位协方差。设列向量样本 $\mathbf{x}_i \in \mathbb{R}^d$ ，均值 $\boldsymbol{\mu}$ ，协方差 $\mathbf{C} = n^{-1} \sum_i (\mathbf{x}_i - \boldsymbol{\mu})(\mathbf{x}_i - \boldsymbol{\mu})^\top$ ，ZCA 形式为

$$\mathbf{z}_i = (\mathbf{C} + \epsilon \mathbf{I})^{-1/2} (\mathbf{x}_i - \boldsymbol{\mu}). \quad (14.44)$$

逆平方根按对称矩阵特征值计算。若 $\epsilon = 0$ 且 $\mathbf{C}$ 正定，样本协方差变为单位矩阵；有稳定项时，变为 $(\mathbf{C} + \epsilon \mathbf{I})^{-1/2} \mathbf{C} (\mathbf{C} + \epsilon \mathbf{I})^{-1/2}$ ，只是近似白化。统计样本不足、协方差奇异和未来分布变化都会影响结果。

图 14.4 显示对角缩放与完整变换的区别。




图 14.4 以 $\mathbf{C} = \begin{pmatrix} 4 & 1.6 \\ 1.6 & 1 \end{pmatrix}$ 构造二维协方差椭圆。左图为原尺度，中图分别除以各坐标标准差，边际尺度相同但相关系数仍为 0.8；右图用精确逆平方根白化后成为圆。曲线是解析示意，不是抽样散点或实验结果；忽略稳定项且不加入可学习仿射。

白化能处理逐坐标缩放保留的相关性，但协方差需要更多观测和矩阵计算，噪声方向还可能被过度放大¹⁵。若将这个变换嵌入网络层，可学习仿射还可能重新引入相关性。固定输入白化只用训练数据拟合并保存变换，不能持续校正网络内部随参数更新而改变的响应。

网络内的白化层。 若希望持续处理隐藏特征之间的相关性，可以把白化嵌入网络层，但需要在前向计算协方差，并在反向处理该矩阵的依赖。**去相关批归一化** (DBN) 采用 ZCA 白化，分组实现减少矩阵规模但舍去组间相关性；**迭代归一化** (IterNorm) 用矩阵迭代近似逆平方根，避免直接特征分解。两者利用比对角标准化更完整的方向关系，也增加矩阵存储、统计误差与近似选择。这里的矩阵迭代处理协方差，与 Muon 对更新奇异值整形的目标不同。

¹⁵ L. Huang, D. Yang, B. Lang, J. Deng, *Decorrelated Batch Normalization* In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2018; L. Huang, Y. Zhou, F. Zhu, L. Liu, L. Shao, *Iterative Normalization: Beyond Standardization towards Efficient Whitening* In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2019

14.3.1.2 批归一化

批归一化用同一特征或通道的多个观测建立参照。相关方法围绕这一批统计机制，调整统计伙伴、训练与推理的参照、历史状态或输出仿射。

如果同一通道的整体响应尺度随训练变化，可以用共同统计伙伴提供尺度参照，并让网络学习输出幅度。代价是单个样本的计算与其他伙伴耦合，这又联系到第14.1.3节的批量组织。**批归一化**（batch normalization, BatchNorm）让同一特征在当前批量中的观测共同决定尺度。对全连接层 $\mathbf{X} \in \mathbb{R}^{b \times d}$ ，固定特征 j ，统计 $\{X_{i,j} : i = 1, \dots, b\}$ ；对卷积张量，固定通道 j ，再把批量与空间位置一起统计。每个特征或通道有一组 γ_j, ζ_j ¹⁶。

以卷积通道为例，训练时计算

$$\begin{aligned} \mu_j &= \frac{1}{bhw} \sum_{i,u,v} X_{i,j,u,v}, & v_j &= \frac{1}{bhw} \sum_{i,u,v} (X_{i,j,u,v} - \mu_j)^2, \\ Y_{i,j,u,v} &= \gamma_j \frac{X_{i,j,u,v} - \mu_j}{\sqrt{v_j + \epsilon}} + \zeta_j. \end{aligned} \quad (14.45)$$

训练时用本批的 μ_j, v_j 计算输出，所以一个样本的输出依赖其他统计伙伴。同时维护供推理使用的**运行均值**（running mean）和**运行方差**（running variance），即随训练批次更新、保存在模型中的滑动统计量。令 $\rho \in [0, 1)$ 为旧统计量的保留系数，一种更新约定为

$$\begin{aligned} \bar{\mu}_j^{(t)} &= \rho \bar{\mu}_j^{(t-1)} + (1 - \rho) \mu_j^{(t)}, \\ \bar{v}_j^{(t)} &= \rho \bar{v}_j^{(t-1)} + (1 - \rho) v_j^{(t)}. \end{aligned} \quad (14.46)$$

这里 t 标记训练批次。式(14.45)用于当前前向的 $v_j^{(t)}$ 以 $m = bhw$ 为分母；更新运行方差所用的 $\bar{v}_j^{(t)}$ 则须按实现约定：可以使用同一批方差，也可以在 $m > 1$ 时使用 $m v_j^{(t)} / (m - 1)$ 。后一种是独立同分布观测下的无偏方差估计，不能在空间观测相关时直接称为无偏，也不能把它与前向的分母 m 混为一谈。接口中的 momentum 可能指 ρ ，也可能指新批权重 $1 - \rho$ ，需查明定义。

采用运行统计的常规 BN 在推理时冻结 $\bar{\mu}_j, \bar{v}_j$ ，既不重新计算推理批次的均值、方差，也不继续更新滑动统计；只把式(14.45)中的 μ_j, v_j 换成保存值。因而同一输入的 BN 输出不再随推理批次的伙伴改变。运行统计是历次批统计的加权估计，还受初始化、采样和训练中参数变化影响，不是当前小批量统计，也不等于在最终参数下遍历全训练集得到的精确统计。关闭运行统计跟踪等配置会改变这一行为，不能只凭“推理模式”推断所用参照。

若统计集合只有一个元素，中心化后为 0，归一化不能保留该元素的变化。卷积中即使 $b = 1$ ，空间位置仍可提供多个元素，但高度相关的位置

¹⁶ S. Ioffe, C. Szegedy, *Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift* In Proceedings of the 32nd International Conference on Machine Learning, 2015, pp. 448–456

并不等同于独立样本。小批量、单类别采样或相邻视频帧都可能使统计量偏离预期使用分布。选择伙伴比只查看名义批量更重要。

固定运行统计量后, BatchNorm 是通道仿射变换, 可与前面的线性层或卷积折叠, 第13.3.3节给出公式。训练时则不能折叠成同一固定变换, 因为当前批量统计会变化, 求导也包含统计量依赖。验证、推理和模型导出需要采用一致模式。

BatchNorm 调节表示尺度, 并通过重参数化影响梯度与优化形状。原始工作用内部协变量偏移说明动机, 后续研究指出训练收益不能简单归因于阻止中间分布变化, 在所研究设置中还体现为更平滑的优化行为。这类解释应保留其研究条件, 不能视为所有结构上的统一定理¹⁷。

批统计范围的调整。 批归一化的统计伙伴未必与一次参数更新使用的样本集合一致。同步与幽灵批归一化分别扩大和缩小伙伴集合, 处理局部批量不足与过大统计集合的问题。分布式训练中, 每台设备的局部批量可能很小。**同步批归一化** (synchronized BatchNorm, SyncBatchNorm) 跨指定设备集合共同统计。设设备 r 有 N_r 个统计元素、均值 μ_r 和方差 v_r , 正确合并为

$$N = \sum_r N_r, \quad \mu = \frac{\sum_r N_r \mu_r}{N},$$

$$v = \frac{1}{N} \sum_r N_r [v_r + (\mu_r - \mu)^2]. \quad (14.47)$$

直接平均各设备方差会漏掉设备间均值差异, 元素数不同时直接平均均值也不对。同步改变统计伙伴并增加通信; 它不会把相关数据自动变为独立数据。大型批量检测中的同步统计是其典型使用情形¹⁸。

当优化批量很大, 又希望保留较小统计集合时, **幽灵批归一化** (Ghost BatchNorm) 将同一次优化批量分成较小子组, 各组分别计算归一化统计, 再合并梯度更新。它区分“有多少样本决定一次更新”与“有多少样本共同决定一次归一化”, 不是梯度累积的另一个名字¹⁹。

这两种做法的优势是可以单独选择统计批量, 而不必同步改变优化批量。SyncBatchNorm 增加通信, Ghost BatchNorm 增加统计波动; 扩大或缩小伙伴都需要验证。若困难来自训练与推理参照不同, 还需要下面的统计校正。

参照批量与训练推理校正。 小批量或非独立采样可能使当前统计波动, 训练与推理的参照又不同。相关方法通过调整参考批量或校正批统计, 缓解参照差异²⁰。**虚拟批归一化** (virtual batch normalization, VBN) 将当前样本与固定参考批量结合, 减少对工作批量中其他新样本的依赖; 参考集合的偏差与额外计算仍会保留。这里的“虚拟批”不是用梯度累积模拟大优

¹⁷ S. Santurkar, D. Tsipras, A. Ilyas, A. Madry, *How Does Batch Normalization Help Optimization?* In Advances in Neural Information Processing Systems 31, 2018, pp. 2483–2493

¹⁸ C. Peng, T. Xiao, Z. Li, Y. Jiang, X. Zhang, K. Jia, G. Yu, J. Sun, *MegDet: A Large Mini-Batch Object Detector* In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2018

¹⁹ E. Hoffer, I. Hubara, D. Soudry, *Train Longer, Generalize Better: Closing the Generalization Gap in Large Batch Training of Neural Networks* In Advances in Neural Information Processing Systems 30, 2017

²⁰ T. Salimans, I. Goodfellow, W. Zaremba, V. Cheung, A. Radford, X. Chen, *Improved Techniques for Training GANs* In Advances in Neural Information Processing Systems 29, 2016; S. Ioffe, *Batch Renormalization: Towards Reducing Minibatch Dependence in Batch-Normalized Models* In Advances in Neural Information Processing Systems 30, 2017

化批量。

批再归一化 (batch renormalization) 把批标准化结果改为 $\hat{x} = r(x - \mu_B)/\sigma_B + d$ 。 r 由批标准差与运行标准差之比得到, d 由两种均值之差得到, 二者均按调度裁剪并停止梯度。未裁剪时, 前向等于使用运行统计; 反向仍通过批内统计求导。它缓解两种参照的差异, 却增加运行状态和校正范围的选择。

流式与历史统计。 在流式或微批量条件下, **在线归一化** (OnlineNorm) 沿样本流维护统计并设计相应的反向校正; **PowerNorm** 用运行平方均值和近似反向处理管理 Transformer 中的批尺度波动²¹。它们让参照跨时间积累, 代价是状态次序、重置规则与分布变化后的滞后。完整方法不能简化为随意加入一个移动平均, 也不能使用当前预测时尚不可见的未来样本。

条件批归一化与空间调制。 生成任务要让共享内容表示随条件改变, 固定仿射只能提供同一组尺度。**条件归一化** 让条件 c 产生 $\gamma(c), \zeta(c)$, 计算 $y = \gamma(c) \odot \hat{x} + \zeta(c)$ 。条件化改变仿射参数的来源, 并不自动改变统计伙伴; 同一思路也可用于后面的层归一化与实例归一化。图 14.5 展示内容与条件两条路径。




图 14.5 条件归一化的共同计算图。蓝色内容路径产生 $\hat{x}$, 红色条件映射产生缩放 γ 与偏移 ζ , 圆形节点分别表示逐元素乘法与加法。条件既可以是风格统计, 也可以是类别、文本或时间等输入; 空间调制还让仿射参数随位置变化。

条件 BatchNorm 保留批统计, 让类别、文本等条件产生通道仿射参数。**空间自适应归一化** (SPADE) 让语义布局产生随位置变化的缩放与偏移, 把布局条件送回归一化后的特征。原工作使用同步批统计, 因此在这里介绍; 如果底层换为 InstanceNorm, 则应按实例范围理解。条件编码增加参数与计算, 且仍需核对底层统计在训练和推理中的行为²²。

时间展开的批统计。 脉冲分布随时间变化时, **时间展开批归一化** (BNTT) 为不同时间步设置统计与参数, 使各时刻拥有相应尺度参照。它保持批归一化的统计范围, 增加了时间索引, 因此归入本类。代价是更多状态, 推理窗口改变时还需处理未训练时刻; 统计应遵守因果边界, 不能将未来输入用于当前输出²³。

²¹ V. Chiley, I. Sharapov, A. Kosson, U. Köster, R. Reece, S. Samaniego de la Fuente, V. Subbiah, M. James, *Online Normalization for Training Neural Networks* In Advances in Neural Information Processing Systems 32, 2019; S. Shen, Z. Yao, A. Gholami, M. W. Mahoney, K. Keutzer, *PowerNorm: Rethinking Batch Normalization in Transformers* In Proceedings of the 37th International Conference on Machine Learning, 2020, pp. 8741–8751

²² T. Park, M.-Y. Liu, T.-C. Wang, J.-Y. Zhu, *Semantic Image Synthesis with Spatially-Adaptive Normalization* In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2019

²³ Y. Kim, P. Panda, *Revisiting Batch Normalization for Training Low-Latency Deep Spiking Neural Networks From Scratch* In Frontiers in Neuroscience, 2021, vol. 15, 773954

与通道组统计和激活的组合。微批量下，批尺度校正还可以与样本内的通道组处理串联。**批通道归一化**（BCN）采用这类组合，并与参数侧的权重标准化配合。它增加了样本内统计，但保留批或历史参照的依赖；详细效果取决于统计与运行状态的实现，不能仅视为更换了批量大小²⁴。

EvoNorm 把归一化与非线性共同设计。B 系列使用批统计，B0 还将批方差与实例方差结合，因而具有跨样本依赖，也需维护推理统计。它与先 BatchNorm 再激活的计算不同；替换时需核对整个模块。使用样本内组统计的 S0 放在第14.3.1.5节介绍²⁵。

14.3.1.3 层归一化

这一类在单个样本的指定表示内部建立尺度参照，不借用其他样本。相关方法保留这一作用范围，改变是否中心化、如何计算长度以及仿射参数的来源；层归一化在残差块中的放置方式也在本类内说明。

批量组成或大小变化时，跨样本参照可能不适合当前表示。LayerNorm 把尺度参照移到同一个样本表示内部，隔离其他样本对这一步局部导数的影响。变长序列和不同推理批量需要在单个表示内管理尺度。**层归一化**（layer normalization, LayerNorm）对选定表示中的多个特征共同计算均值与方差。对 $\mathbf{X} \in \mathbb{R}^{b \times n \times d}$ ，Transformer 通常固定样本 i 与词元位置 t ，在特征维 $j = 1, \dots, d$ 上统计，使用式(14.42)，仿射参数 $\gamma, \zeta \in \mathbb{R}^d$ 跨样本和位置共享²⁶。

其他样本和其他位置不参与当前词元的统计，训练与推理均使用当前表示。因此，逐词元 LayerNorm 不依赖批量组成，也不需要保存运行均值与方差。变长掩码仍要在注意力、池化和损失中正确使用；LayerNorm 不会替代这些处理。

“层”并不自动规定整个张量都是统计集合。对图像，可以选定全部通道及空间位置，也可以只在每个位置跨通道统计；两种形状会保留不同信息。整样本 LayerNorm 的仿射参数还可能逐元素设置，GroupNorm 则通常逐通道设置，即使统计范围相同也未必是同一个完整映射。

若忽略 ϵ ，对 $\mathbf{x}$ 加同一个常数或乘以同一个正数，不改变中心化后的标准化表示。它消去的是共同平移与尺度，保留相对特征关系。若任务需要共同幅值，应依靠保留路径或其他设计保存，而不能期待固定 γ, ζ 恢复每个输入被删去的任意信息。

均方根归一化。式(14.43)中的中心化会消去共同平移方向；如果只想管理幅度，这一步未必必要。RMSNorm 保留未中心化表示，再由平方幅度决定尺度。**均方根归一化**（root mean square normalization, RMSNorm）对

²⁴ S. Qiao, H. Wang, C. Liu, W. Shen, A. Yuille, *Micro-Batch Training with Batch-Channel Normalization and Weight Standardization* In Proceedings of the European Conference on Computer Vision, 2020

²⁵ H. Liu, A. Brock, K. Simonyan, Q. V. Le, *Evolving Normalization-Activation Layers* In Advances in Neural Information Processing Systems 33, 2020

²⁶ J. L. Ba, J. R. Kiros, G. E. Hinton, *Layer Normalization* In arXiv preprint arXiv:1607.06450, 2016

$\mathbf{x} \in \mathbb{R}^d$ 采用

$$y_j = \gamma_j \frac{x_j}{\sqrt{d^{-1} \sum_{k=1}^d x_k^2 + \epsilon}} \quad (14.48)$$

基本形式不减均值，也不加入偏移参数。它使表示对共同正尺度变化近似不敏感，但不对共同平移不敏感；分母同时包含方差与均值平方，因为 $d^{-1} \sum_j x_j^2 = v + \mu^{227}$ 。

示例 14.1 减去均值改变了哪些信息 取两个仅相差共同偏移的向量：

$$\mathbf{x} = (1, 2, 3)^\top, \quad \mathbf{x}' = (11, 12, 13)^\top.$$

忽略 ϵ 并令仿射缩放为 1，LayerNorm 的两次输出都为

$$(-\sqrt{3/2}, 0, \sqrt{3/2})^\top.$$

共同偏移 10 被消去。RMSNorm 分别给出 $\mathbf{x}/\sqrt{14/3}$ 与 $\mathbf{x}'/\sqrt{434/3}$ ，结果不同。二者都控制尺度，但保留的信息不同。

RMSNorm 省去中心化与偏移，统计操作较少，并保留共同偏移对方向和分母的影响；这不同于保留任意原始幅度，因为共同缩放仍被消去。是否比 LayerNorm 更适合，应结合任务需要的信息与实际算子成本判断。

部分统计与整体长度。 部分 RMSNorm (pRMSNorm) 只用特征子集估计均方根，以减少统计量的归约计算。节省来自少统计一些元素，风险是子集不能代表完整幅度，算子实现也决定它是否实际更快。

有些任务关心向量方向，或希望仅管理局部响应的幅度。**ScaleNorm** 采用 $\mathbf{y} = \mathbf{g}\mathbf{x} / \max(\|\mathbf{x}\|_2, \epsilon)$ ，只学习一个整体长度 g ；**FixNorm** 固定嵌入长度，普通 L2 归一化则得到单位向量。它们计算简单，适合将方向用于相似性，但会删除绝对幅度；逐特征可学习缩放与整体长度并不等价²⁸。

图像位置与注意力向量的长度。 **PixelNorm** 在单个图像位置跨通道计算均方根，基本形式没有仿射与中心化；PGGAN 用它管理生成器特征幅度。按统计范围，它与逐位置 RMS 缩放相近，所以放在层内特征尺度方法中；它不等于对整幅图计算 LayerNorm，也会消去原始幅度²⁹。

查询-键归一化 (QKNorm) 在每个注意力头内归一化单个查询和键向量的长度，以可学习系数缩放余弦得分。它同样只处理当前向量的特征维，目的是减少长度增长引起的 Softmax 饱和。它管理注意力评分的尺度，不能替代残差块的 LayerNorm 或 RMSNorm，仍需选择合适的评分温度³⁰。

²⁷ B. Zhang, R. Sennrich, *Root Mean Square Layer Normalization* In arXiv preprint arXiv:1910.07467, 2019

²⁸ T. Q. Nguyen, J. Salazar, *Transformers without Tears: Improving the Normalization of Self-Attention* In Proceedings of the 16th International Conference on Spoken Language Translation, 2019

²⁹ T. Karras, T. Aila, S. Laine, J. Lehtinen, *Progressive Growing of GANs for Improved Quality, Stability, and Variation* In International Conference on Learning Representations, 2018

³⁰ A. Henry, P. R. Dachapally, S. S. Pawar, Y. Chen, *Query-Key Normalization for Transformers* In Findings of the Association for Computational Linguistics: EMNLP 2020, 2020, pp. 4246–4253

条件层归一化。当输出需要随类别、文本或时间等条件变化时，**自适应 LayerNorm** (AdaLN) 在层统计之后使用条件仿射，条件 RMSNorm 则保留均方根统计。二者沿用图 14.5 的两条路径，改变的是仿射来源。DiT 中的 AdaLN-Zero 还把残差条件门初始化为 0，让初始分支较弱；“Zero”指门与相应仿射的初始化，不是永久输出 0。底层统计、条件网络与残差门须分别说明³¹。

残差块中的放置与尺度配合。层归一化的统计范围不变，放置位置与残差尺度仍会改变第 14.1.4 节的雅可比连乘³²。Pre-LN 残差块形如 $\mathbf{h}' = \mathbf{h} + F(\text{LN}(\mathbf{h}))$ ，Post-LN 形如 $\mathbf{h}' = \text{LN}(\mathbf{h} + F(\mathbf{h}))$ 。前者保留未经过本步归一化的直接路径，后者对合并结果共同归一化；输出尺度、梯度路径和初始化需求不同，第 12.2.4 节展开了具体结构。

直接路径有利于把梯度送回较早层，但 Pre-LN 分支仍可能很弱，整体尺度仍需管理；Post-LN 约束合并后的表示，却让归一化导数进入每个块的传播。选择位置应配合残差尺度与初始化。

NormFormer 增加归一化位置与尺度调节，DeepNorm 配合残差缩放和初始化支持更深堆叠；二者是块组织方案，不能只替换一个方差公式就复现。增加操作或改变系数也有成本，应检查完整计算图与初始化条件。

14.3.1.4 实例归一化

图像外观可能随样本变化，共享批统计未必能去掉每幅图各通道的独有尺度。InstanceNorm 在该样本通道内部建立参照，代价是可能同时去掉有用的外观幅度。图像中，某个通道的均值与对比度可能更多描述风格，而非内容。**实例归一化** (instance normalization, InstanceNorm) 固定样本 i 和通道 j ，只在 (u, v) 上计算均值与方差。常见实现不使用跨样本运行统计，训练与推理都归一化当前输入；可选仿射参数按通道共享³³。

它把每个样本的每个通道都调整到相近统计尺度，有利于去除某些外观差异，却也可能消去任务需要的亮度或强度。若空间只剩一个元素，中心化会退化；若启用运行统计，推理性质又不同。因此，名称之外仍要说明空间形状、仿射参数和运行统计配置。

自适应实例归一化。若希望内容保留空间结构，同时采用另一幅图的通道统计，可以在实例标准化后重设均值与幅度。**自适应实例归一化** (AdaIN) 用风格特征的通道均值和标准差重设内容统计，形式为 $\sigma(\mathbf{s}) \odot [\mathbf{x} - \mu(\mathbf{x})] / \sigma(\mathbf{x}) + \mu(\mathbf{s})$ ，零方差需稳定处理。它保留实例统计范围，把固定仿射换为风格统计；这种匹配方便注入外观条件，但不保证感知风格完全一致³⁴。

³¹ W. Peebles, S. Xie, *Scalable Diffusion Models with Transformers* In Proceedings of the IEEE/CVF International Conference on Computer Vision, 2023

³² S. Shleifer, J. Weston, M. Ott, *NormFormer: Improved Transformer Pretraining with Extra Normalization* In arXiv preprint arXiv:2110.09456, 2021; H. Wang, S. Ma, L. Dong, S. Huang, D. Zhang, F. Wei, *DeepNet: Scaling Transformers to 1,000 Layers* In arXiv preprint arXiv:2203.00555, 2022

³³ D. Ulyanov, A. Vedaldi, V. Lempitsky, *Instance Normalization: The Missing Ingredient for Fast Stylization* In arXiv preprint arXiv:1607.08022, 2016

³⁴ X. Huang, S. Belongie, *Arbitrary Style Transfer in Real-time with Adaptive Instance Normalization* In Proceedings of the IEEE International Conference on Computer Vision, 2017

不减均值的滤波响应归一化。 如果希望在每个样本的每个通道内管理幅度,又保留共同偏移的影响,可以在相同空间范围内改用未中心化的平方幅度。**滤波响应归一化**(FRN)沿这一范围计算均方根,不减均值,再使用仿射和可学习阈值激活。按作用范围将它放在本类,但它与标准 InstanceNorm 的映射不同;完整模块还包含激活,空间很小时稳定项与信息损失尤须注意³⁵。

14.3.1.5 组归一化

统计集合太小会使尺度估计不稳定,全部通道混合又可能过于粗糙。Group-Norm 在样本内部选择中间大小的通道组,在信息粒度与统计元素数之间取舍。**组归一化**(group normalization, GroupNorm)将 c 个通道预先划为 g 组,在单个样本内对组内通道及空间位置共同统计。等分时要求 c 能被 g 整除,每组统计元素数为 $(c/g)hw$,仿射参数通常仍逐通道设置³⁶。

当 $g = c$ 时,统计范围与 InstanceNorm 相同;当 $g = 1$ 时,与整样本 LayerNorm 相同。完整映射仍需核对仿射参数和运行统计配置。组数控制哪些特征共同决定尺度,而不是一个总能越大越好的精度参数。

组统计与非线性的联合计算。 组归一化后再接激活,会让两步导数共同进入反向传播。上文 EvoNorm 系列中的 S0 直接联合这两部分,采用 $y_j = \gamma_j x_j \sigma(a_j x_j) / \sqrt{v_G + \epsilon} + \zeta_j$, 其中 v_G 是样本内通道组的中心化方差, a_j 可学习, σ 为 Sigmoid。它使用组统计,分子却不减均值,因此不是先 GroupNorm 再 SiLU。联合计算需要作为完整模块替换,不能随意重复添加相同激活。

图 14.6 用同一构造数据比较已讨论的批、层、实例和组统计。图中采用常见轴名 N, C, H, W , 分别对应前文的批量 b 、通道 c 、高 h 和宽 w ; 元素索引写作 (n, c, h, w) 。图将 (h, w) 展开为行、通道 c 排成列,两张小表分别表示样本 $n = 1, 2$ 。轮廓内的着色格共同计算均值与方差,圈出的目标元素始终不变,因而可以直接比较哪些伙伴被加入或排除。

BN 固定 c , 跨 n, h, w 统计; IN 固定 n, c , 只跨 h, w , 并不跨实例。GN 固定 n 和通道组,跨组内 c 及 h, w 。图中的 LN 明确采用图像整样本约定: 固定 n , 统计全部 C, H, W 。Transformer 的逐词元 LN 则固定样本 n 和词元位置 t , 只沿特征 C (前文记为 d) 统计; 不能把图中整幅图像的 LN 范围照搬到整个序列。选择统计伙伴改变数值结果,也改变式(14.43)中哪些特征共同参与导数。

³⁵ S. Singh, S. Krishnan, *Filter Response Normalization Layer: Eliminating Batch Dependence in the Training of Deep Neural Networks* In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2020, pp. 11237–11246

³⁶ Y. Wu, K. He, *Group Normalization* In Proceedings of the European Conference on Computer Vision, 2018, pp. 3–19




图 14.6 在 $N = 2, C = 4, H = W = 2$ 的图像张量上，对同一元素 $X_{1,2,1,2} = 6$ 比较统计伙伴。按样本、空间行、通道的展示顺序填入教学数值 1 至 32，每行标出 (h, w) ；并非按张量存储顺序编号。蓝、紫、青、橙分别标出 BN、LN、IN、GN 的统计集合，边界轮廓及 n 、 c 、 (h, w) 标签提供颜色之外的读法，深色圈为目标元素。GN 取通道组 $\{1, 2\}$ ；LN 统计整幅图像的 CHW，不是 Transformer 逐词元的特征维 LN；图中未加入仿射变换。

表 14.3 将范围写成索引，便于在不同张量排列下实现。位置、通道和批量放在第几个维度可以改变，但统计伙伴的语义必须保持。

方法	固定的索引	共同计算统计量的索引
BatchNorm	通道 j	样本 i 、位置 u, v
LayerNorm (整样本)	样本 i	通道 j 、位置 u, v
LayerNorm (每位置)	样本 i 、位置 u, v	通道 j
InstanceNorm	样本 i 、通道 j	位置 u, v
GroupNorm	样本 i 、通道组	组内通道 j 、位置 u, v

表 14.3 在 $\mathbf{X} \in \mathbb{R}^{b \times c \times h \times w}$ 上比较基本统计范围。每位置 LayerNorm 与序列中的逐词元形式对应；整样本形式与 $g = 1$ 的 GroupNorm 仅在统计范围上相同。RMSNorm 也需明确形状，但统计的是平方均值而非中心化方差。

14.3.2 参数归一化

前面的基本方法管理表示统计，权重方法则直接改变线性映射的参数化。它们不需要当前批量提供尺度参照，但各自控制的量不同：向量长度、滤波器均值与方差、整矩阵的最大放大不能互相代替。

14.3.2.1 权重归一化

第 14.1.2 节指出重参数化可以改变更新几何。WeightNorm 把长度与方向作为不同变量，让优化器分别调整两种自由度，无需估计激活的批统计。激活统计依赖数据，权重尺度还可以直接通过重参数化管理。**权重归一化** (weight normalization, WeightNorm) 把非零权重向量写为

$$\mathbf{w} = g \frac{\mathbf{v}}{\|\mathbf{v}\|_2}, \quad (14.49)$$

其中 g 是可训练标量， $\mathbf{v}$ 决定方向。对卷积可按输出滤波器分别使用，对线性层可按行使用。它不需要当前批量，也不直接保证激活均值为 0³⁷。

设原权重梯度为 $\mathbf{a} = \nabla_{\mathbf{w}} \mathcal{L}$ ，链式法则给出 $\partial \mathcal{L} / \partial g = \mathbf{v}^\top \mathbf{a} / \|\mathbf{v}\|_2$ ，以及

$$\nabla_{\mathbf{v}} \mathcal{L} = \frac{g}{\|\mathbf{v}\|_2} \left(\mathbf{I} - \frac{\mathbf{v} \mathbf{v}^\top}{\|\mathbf{v}\|_2^2} \right) \mathbf{a}. \quad (14.50)$$

方向梯度包含垂直投影，因此更新 $g, \mathbf{v}$ 与直接更新 $\mathbf{w}$ 的轨迹不同。 $\mathbf{v} = \mathbf{0}$ 需要由初始化和数值处理避免。固定每行长度也不能控制整个矩阵的最大放大：例如两行都为 $(1, 0)$ 时，矩阵谱范数为 $\sqrt{2}$ ，超过单行长度 1。

14.3.2.2 权重标准化

滤波器自身的均值和尺度会影响初始及后续响应，批量很小时也难以依靠稳定批统计补偿。WS 直接处理权重分布，使这一尺度管理与当前样本伙伴分开。**权重标准化** (weight standardization, WS) 不只分离长度，还对

³⁷ T. Salimans, D. P. Kingma, *Weight Normalization: A Simple Reparameterization to Accelerate Training of Deep Neural Networks* In *Advances in Neural Information Processing Systems* 29, 2016

每个滤波器的权重减均值并按标准差缩放。将第 i 个输出滤波器展平为 d 个元素，采用

$$\begin{aligned}\mu_i^W &= \frac{1}{d} \sum_j W_{i,j}, & v_i^W &= \frac{1}{d} \sum_j (W_{i,j} - \mu_i^W)^2, \\ \bar{W}_{i,j} &= \frac{W_{i,j} - \mu_i^W}{\sqrt{v_i^W + \epsilon}}.\end{aligned}\quad (14.51)$$

实际卷积使用 $\bar{\mathbf{W}}$ ，反向穿过权重统计更新原始 $\mathbf{W}$ 。它管理的是滤波器参数分布，与在样本或位置上统计的 GroupNorm 可以组合。微批量训练中的 WS 与 BCN 研究了这类互补作用，不能把其中任何一个自动当成另一个的替代³⁸。

WS 不保证输出激活的统计，因为输出还依赖输入和空间结构。

缩放权重标准化。 带增益和扇入校正的缩放权重标准化继续作用于滤波器参数。NFNet 把它与残差信号尺度、激活修正和自适应梯度裁剪配合，以减少通常的激活批统计依赖。这属于参数尺度与结构共同设计，不能仅凭权重标准化公式复现整套网络³⁹。

14.3.2.3 谱归一化

激活方差或每行长度并不控制所有方向的最大放大。第14.1.4节使用的算子上界，需要与最大奇异值相关的控制，谱归一化因此关注另一种尺度。若目标是控制线性映射的最大放大，需约束算子范数。**谱归一化** (spectral normalization) 对非零矩阵采用 $\bar{\mathbf{W}} = \mathbf{W} / \sigma_{\max}(\mathbf{W})$ ， $\sigma_{\max}$ 为最大奇异值。计算中常以幂迭代近似：交替用 $\mathbf{W}^T \mathbf{u}$ 与 $\mathbf{W} \mathbf{v}$ 并归一化，再估计 $\mathbf{u}^T \mathbf{W} \mathbf{v}$ ⁴⁰。

若估计值小于真实最大奇异值，除法后的真实算子范数仍可能超过 1，有限次迭代不自动给出严格界。零矩阵与很小估计还需稳定处理，是否沿估计向量求导也应按实现说明。

若每层算子范数已受约束，且激活是已知 Lipschitz 映射，普通串联网路的输入敏感度可由尺度乘积控制。残差求和、归一化和注意力需另行计入。卷积核展平矩阵的谱范数与完整空间卷积算子通常不同，不能仅约束核矩阵就宣称整个网络满足相同界。谱归一化控制最大方向，WeightNorm 分离方向与长度，WS 调整滤波器均值和方差，三者目的不同。

14.3.3 其他归一化方法

有些方法混合多个统计范围，有些围绕可逆变换、图结构或通道竞争定义尺度，不能直接归入前面的五类特征统计或三种参数处理。这里按具体计

³⁸ S. Qiao, H. Wang, C. Liu, W. Shen, A. Yuille, *Micro-Batch Training with Batch-Channel Normalization and Weight Standardization* In Proceedings of the European Conference on Computer Vision, 2020

³⁹ A. Brock, S. De, S. L. Smith, K. Simonyan, *High-Performance Large-Scale Image Recognition Without Normalization* In Proceedings of the 38th International Conference on Machine Learning, 2021

⁴⁰ T. Miyato, T. Kataoka, M. Koyama, Y. Yoshida, *Spectral Normalization for Generative Adversarial Networks* In International Conference on Learning Representations, 2018

算作补充；是否采用仍要对应实际训练困难，并评估信息损失、状态与计算成本。

14.3.3.1 混合统计与局部响应

固定统计范围未必适合每一层。**可切换归一化** (SwitchableNorm) 分别计算批、层、实例统计，学习均值和方差的凸组合。它同时使用多个范围，因而不放入单一基础类别。统计混合增加计算，只要批分量存在，就仍需处理跨样本或历史依赖；这与第14.3.1.2节中 BCN 串联不同，后者依次执行映射⁴¹。

局部响应归一化 (local response normalization, LRN) 属于局部除法竞争。第9.3.5.2节中 AlexNet 的一种形式为 $y_j = x_j / (k_0 + a \sum_{r \in N(j)} x_r^2)^\beta$ ，这里省略样本与空间索引， $N(j)$ 是邻近通道， $k_0 > 0, a \geq 0, \beta > 0$ 。强响应会抑制邻域幅度；它既不减均值，也不按前述批、层、实例或固定通道组计算标准差，不能直接替换这些映射。

14.3.3.2 可逆仿射

可逆生成模型需要逐样本可逆、且行列式容易计算的尺度变换。**ActNorm** 用首批数据初始化通道仿射 $Y_{i,j,u,v} = s_j X_{i,j,u,v} + b_j$ ，之后直接学习 s_j, b_j ，不再重估每批统计。取 $s_j = \exp(a_j)$ 可保证非零尺度；单样本对数雅可比行列式为 $hw \sum_j \log |s_j|$ 。其优势是逐样本计算一致、可逆性明确，代价是初始数据影响起点，后续输出不再保证零均值和单位方差⁴²。

14.3.3.3 通道响应与图结构

全局响应归一化 (GRN) 在 ConvNeXt V2 中比较各通道的空间 L2 响应，再将相对强度用于残差调制。它管理通道竞争，不强制单位方差；空间响应与跨通道比较共同进入计算，不能简单当作 InstanceNorm 或 LayerNorm⁴³。

图模型的统计还需尊重每张图的边界。**GraphNorm** 逐图、逐特征统计，以可学习系数决定去掉多少图均值；**PairNorm** 中心化节点后统一缩放总体长度，管理节点间距离；**MessageNorm** 把聚合消息的长度调整为相对节点状态的可学习比例。它们分别处理图级偏移、过平滑与消息幅度，参照对象不相同，不能仅按输出方差选择⁴⁴。

三者都不能恢复已经完全丢失的节点差异。实际使用应分别检查图边界与节点分布、节点间距离，以及消息和状态的相对幅度，再把这些诊断与任务表现联系起来。

⁴¹ P. Luo, J. Ren, Z. Peng, R. Zhang, J. Li, *Differentiable Learning-to-Normalize via Switchable Normalization* In International Conference on Learning Representations, 2019

⁴² D. P. Kingma, P. Dhariwal, *Glow: Generative Flow with Invertible 1x1 Convolutions* In Advances in Neural Information Processing Systems 31, 2018

⁴³ S. Woo, S. Debnath, R. Hu, X. Chen, Z. Liu, I. S. Kweon, S. Xie, *ConvNeXt V2: Co-designing and Scaling ConvNets with Masked Autoencoders* In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2023

⁴⁴ T. Cai, S. Luo, K. Xu, D. He, T.-Y. Liu, L. Wang, *GraphNorm: A Principled Approach to Accelerating Graph Neural Network Training* In Proceedings of the 38th International Conference on Machine Learning, 2021; L. Zhao, L. Akoglu, *PairNorm: Tackling Oversmoothing in GNNs* In International Conference on Learning Representations, 2020; G. Li, C. Xiong, A. Thabet, B. Ghanem, *DeeperGCN: All You Need to Train Deeper GCNs* In arXiv preprint arXiv:2006.07739, 2020

14.3.3.4 统计归一化的替代

尺度也可以由不使用样本统计的非线性压缩管理。2025 年的**动态 Tanh** (DyT) 以 $\gamma \odot \tanh(ax) + \zeta$ 替代部分 Transformer 归一化层，不计算当前表示的均值或方差，因此不能按前述统计范围归类。它展示了另一种尺度控制路线，也要求保留其配套设计和实验范围；不能由此推断任意网络都可以直接删掉归一化⁴⁵。

⁴⁵ J. Zhu, X. Chen, K. He, Y. Le-Cun, Z. Liu, *Transformers without Normalization* In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2025, pp. 14901–14911

14.3.4 归一化方法的比较与选择

比较方法时，可以回到第14.1.2节的方向尺度与第14.1.4节的雅可比连乘。特征归一化改变输入或隐藏表示，参数归一化改变生成映射的权重；二者可能共同改善尺度，但输出方差相近不足以说明训练行为相同。选择时需同时检查以下维度：

- **作用对象。**调整的是输入、隐藏特征还是权重，决定直接改变计算图的哪一部分。
- **统计范围。**跨样本、表示内部、单通道空间或通道组，决定计算依赖和统计元素数；白化还需估计特征间的协方差。
- **保留信息。**是否去均值、固定长度或去相关，决定共同偏移、幅度与方向关系怎样改变。
- **执行条件。**固定训练参照、当前统计还是运行状态，决定训练推理是否一致，以及通信、矩阵计算和条件网络的成本。

表 14.4 比较五类特征方法，表 14.5 比较参数方法，表 14.6 列出具体方法的归属。分类先固定作用对象和统计范围，再比较范围内的公式差异；条件仿射与残差块位置属于相应基础方法的扩展，不另列为一种统计类别。

类别	统计或尺度对象	主要处理	优势与主要边界
白化	观测集合内的特征协方差	中心化与协方差变换	去相关；矩阵计算与统计误差较大
批归一化	同通道的批量与空间位置	批均值、方差或历史尺度	共享尺度参照；批伙伴与推理状态需核对
层归一化	单表示的指定特征维	方差、均方根或向量长度	隔离其他样本；变体保留的信息不同
实例归一化	单样本单通道的空间位置	方差或未中心化平方幅度	管理样本外观；可能删去有用强度
组归一化	单样本组内通道与空间位置	组内统计	不依赖批量；组数改变信息粒度

表 14.4 按作用范围比较特征归一化。白化可采用训练集固定参照或网络内动态协方差；批归一化通常在推理时使用运行统计。其余类别按基本形式使用当前表示，具体变体还需核对中心化、仿射与状态。

方法	管理的参数性质	优势与主要边界
WeightNorm	分开权重方向与长度	不需批统计；行长度不控制整矩阵谱范数
WS 及缩放变体	滤波器均值与方差、增益与扇入尺度	与激活统计分开；不保证输出尺度
SpectralNorm	最大奇异值	管理最大线性放大；近似及算子定义需明确

表 14.5 参数归一化的比较。三者不依赖当前批量，但重参数化或归一化改变优化轨迹；缩放 WS 还需核对具体结构中的配套系数。

归属	方法与相关扩展	需要单独核对的改动
特征：白化	ZCA、DBN、IterNorm	固定或当前协方差、分组与矩阵近似
特征：批归一化	BatchNorm；Sync / Ghost BN、VBN、Batch Renorm、OnlineNorm、PowerNorm、BNTT；条件 BN、SPADE、BCN、EvoNorm-B	伙伴、运行状态、时间索引、条件仿射或联合模块
特征：层归一化	LayerNorm；RMSNorm、pRMSNorm、ScaleNorm、FixNorm、PixelNorm、QKNorm；AdaLN、条件 RMSNorm；Pre / Post-LN、NormFormer、DeepNorm	中心化与长度、条件来源、评分尺度和块位置
特征：实例归一化	InstanceNorm、AdaIN、FRN	风格统计、均方根与阈值激活
特征：组归一化	GroupNorm、EvoNorm-S0	组数与联合非线性
参数归一化	WeightNorm、WS、缩放 WS、SpectralNorm	重参数化、增益与算子尺度
其他方法	SwitchableNorm、LRN、ActNorm、GRN、GraphNorm、PairNorm、MessageNorm、DyT	混合范围、局部竞争、可逆性、图边界或替代统计

表 14.6 具体方法的归属对照。前五行对应第14.3.1节的五类，参数方法见第14.3.2节，其他方法见第14.3.3节。按范围收在一起不表示映射等价；SPADE 的底层统计可配置，BCN 含串联组统计，Pre / Post-LN 等是层归一化的组织方式，DyT 是替代方案。

实际选择从任务信息与执行条件出发。输入量纲差异可先用固定标准化处理，需要去相关时再评估白化及矩阵成本；卷积中批伙伴足够且推理运行统计可靠时，可评估 BatchNorm；批量很小或组成经常改变时，可比较 GroupNorm 及其组数。逐词元序列表示可在层内比较 LayerNorm 与 RMSNorm，重点核对中心化是否有益；需要管理每幅图的通道外观时，再评估 InstanceNorm 与条件扩展。

若目标是控制线性映射的最大放大，应检查参数侧的谱尺度，而不能只看特征方差。条件、混合与特殊结构方法也应在出现对应困难后引入，并在同一数据、结构与预算下检验收益及额外成本。

14.4 参数与结构的改进

优化器处理已经产生的梯度，参数与结构的设计则决定梯度怎样形成、从哪里传回。第14.1.4节的连乘关系说明：深度和长时间递推中的信号损失，不能只靠调整最后的更新步长解决。残差、门控与跨层连接改变计算路径，初始化决定出发时的信号尺度，持续参数约束则管理训练过程中允许的映射。下面分别分析这些机制，避免把初始条件与贯穿训练的约束混在一起。

14.4.1 残差连接

式(14.5)中若每步都只能经过可学习变换, 任何一步的方向收缩都会进入长乘积。**残差连接** (residual connection) 在可学习变换外增加直接路径, 让梯度有机会绕过变换分支。设输入输出同维, 写为

$$\mathbf{h}^{(l+1)} = \mathbf{h}^{(l)} + a_l F_l(\mathbf{h}^{(l)}), \quad \mathbf{J}_{l+1} = \mathbf{I} + a_l \mathbf{J}_{F_l}. \quad (14.52)$$

其中 a_l 为分支尺度, $\mathbf{J}_{F_l}$ 为分支雅可比。原来的纯变换连乘改为含恒等项的连乘; 分支在初始阶段较小时, 网络可以从接近恒等映射的状态开始学习调整。这是传播路径的改变, 并非对每一层输出强制归一化。

恒等项不保证任意深度下梯度稳定。若 $a_l \mathbf{J}_{F_l} = -\mathbf{I}$, 一层雅可比仍可为 0; 若每层都沿同一方向放大, 连乘仍可能增长。一个粗上界为 $\prod_l (1 + |a_l| \|\mathbf{J}_{F_l}\|_2) \leq \exp(\sum_l |a_l| \|\mathbf{J}_{F_l}\|_2)$, 它说明分支尺度和总深度需要共同考虑。具体初始化、归一化与尺度方案要结合网络分析, 而不能无条件宣称某个深度缩放最优。

当维度改变时, 路径写为 $\mathbf{P}_l \mathbf{h}^{(l)} + F_l(\mathbf{h}^{(l)})$, 投影 $\mathbf{P}_l$ 代替恒等矩阵。下采样和投影可能丢失部分方向, 因而需区别恒等捷径与投影捷径。第9章的 ResNet 与第12章的残差块均是这一框架的具体组织。

14.4.2 门控连接

恒等捷径以固定系数传递输入, 不能根据当前内容选择保留哪些信息。**门控连接** (gated connection) 把路径系数变成输入相关变量, 在保留原状态与使用新计算之间调节比例。一个耦合门形式为

$$\mathbf{h}^{(l+1)} = (\mathbf{1} - \mathbf{g}_l) \odot \mathbf{h}^{(l)} + \mathbf{g}_l \odot F_l(\mathbf{h}^{(l)}), \quad \mathbf{g}_l = \sigma(G_l(\mathbf{h}^{(l)})). \quad (14.53)$$

门接近 0 时主要保留输入, 接近 1 时主要使用新计算。Highway 网络在深度方向采用此类选择, LSTM 的遗忘门和输入门则在时间方向分别控制保留与写入; 这些门可以独立, 不一定总和为 1。GRU 的更新门在旧状态与候选状态之间调节比例, 重置门控制候选计算对历史的使用。

把门视为当前固定值时, 保留项的局部导数为 $\text{diag}(\mathbf{1} - \mathbf{g}_l)$ 。如果门依赖输入, 完整雅可比还包含 $\text{diag}(F_l(\mathbf{h}) - \mathbf{h}) \mathbf{J}_{g_l}$, 不能省略后再当成精确推导。时间方向上, 长段保留门的乘积仍可能衰减; 门长期饱和还会使门参数自身难学。初始化门偏置可以改变初始保留倾向, 但是否有利取决于所需记忆长度和写入需求。

14.4.3 跨层连接与密集连接

深层信息不一定都应逐层压缩后才被使用。跨层连接给后续变换直接读取早期特征的入口，同时为反向建立较短路径；拼接再决定这些信息是否保留独立坐标。残差相加要求两路表示在对应坐标上合并。跨层拼接则把来自不同层的表示同时交给后续计算。**密集连接**（dense connection）令第 l 层读取之前多层的特征，例如

$$\mathbf{h}^{(l)} = F_l([\mathbf{h}^{(0)}; \mathbf{h}^{(1)}; \dots; \mathbf{h}^{(l-1)}]), \quad (14.54)$$

分号表示沿特征维拼接。早期特征可经较短路径进入后面层，且保留独立坐标；后续层再学习使用哪些信息。第9章的 DenseNet 通过增长率与过渡层控制通道规模。

相加不会仅因合并而增加宽度，拼接会增加宽度与激活存储。若每层新增 k 维特征，初始宽度为 d_0 ，第 l 层输入宽度为 $d_0 + (l-1)k$ ；在每层采用完整线性投影到 k 维的简化模型中，总权重数为 $\sum_l k[d_0 + (l-1)k] = O(Lkd_0 + L^2k^2)$ 。真实卷积、瓶颈和过渡层改变常数及规模，不能由“特征复用”直接推出总参数更少。

较长的跳跃连接也可把编码器的高分辨率特征交给解码器，减少信息必须经过压缩瓶颈的程度。连接提供了可用路径，模型是否利用它仍取决于后续变换和训练目标；错误的尺寸对齐或相加语义会破坏这一作用。训练时还需保存所引用的激活，因此短梯度路径与低存储成本并不总能同时获得。

14.4.4 参数初始化

在第14.1.4节的连乘尚未被数据更新改变前，初始权重已经决定信号是否容易传播。初始化通过打破对称和安排尺度，为后续优化提供可用起点。全零初始化使同层对称单元收到相同信号，随机初始化打破对称性；尺度过大或过小，又可能让表示与梯度迅速放大或衰减。**方差保持初始化**（variance-preserving initialization）按输入输出连接数与激活特性设置随机权重尺度，目的是在近似独立、零均值等假设下保持前向或反向的平均平方幅度。

对线性或近似线性激活，常见 Xavier 尺度为 $\text{Var}(W_{i,j}) = 2/(d_{\text{in}} + d_{\text{out}})$ ；对 ReLU 前向传播，He 尺度为 $2/d_{\text{in}}$ 。后者中的 2 补偿对称输入下 ReLU 约保留一半平方幅度的效应。卷积中的 d_{in} 要计入核位置与输入通道；分组连接、残差求和和门控则需按实际结构修正。第8章已经给出逐层初始化推导⁴⁶。

正交初始化（orthogonal initialization）令方阵权重满足 $\mathbf{W}^T \mathbf{W} = \mathbf{I}$ ，线性映射保持欧氏范数；矩形权重则只能在相应子空间或行、列方向具有类

⁴⁶ K. He, X. Zhang, S. Ren, J. Sun, *Delving Deep into Rectifiers: Surpassing Human-Level Performance on ImageNet Classification* In Proceedings of the IEEE International Conference on Computer Vision, 2015, pp. 1026–1034

似性质。**恒等初始化** (identity initialization) 将适当的方阵设为单位矩阵, 让初始线性路径直接传递状态。两者只约束初始权重, 后续无约束更新会改变这些性质, 非线性激活也会改变整体雅可比。

第二卷“基础、理论和可信性”的“深度学习的可学习性”章“基于参数梯度初始值的可学习性”节通过初始参数梯度和核矩阵说明, 起点不只决定激活方差, 也决定最初可用的学习方向。实际有限宽度网络可能离开近似固定核的区域, 因而初始化仍需结合结构检查; 它提供合适出发点, 不保证整个训练过程一直保持相同谱性质。

14.4.5 参数约束

初始化改善出发时的传播, 无约束更新却可能逐渐破坏它。若希望训练期间持续限制线性映射, 可通过投影、结构化参数化或惩罚维持约束。这对应第14.1.4节中每一步雅可比尺度的管理, 而不是仅在第0步选择一个矩阵。

约束要写进参数生成或更新过程。暂定更新不满足硬约束时, 投影会把它改成可行参数; 结构化参数化从一开始就生成可行矩阵; 惩罚则允许暂时甚至持续违反, 只通过损失和梯度增加代价。因而“约束”通常不表示每步检查失败就报错或停止训练。下面把三种做法展开。

14.4.5.1 先更新, 再投影回可行集合

设允许的参数集合为非空闭集 $\mathbf{C}$, 先由优化器算出暂定值 $\hat{\boldsymbol{\theta}}^{(t)}$, 再取

$$\boldsymbol{\theta}^{(t)} \in \arg \min_{\mathbf{z} \in \mathbf{C}} \frac{1}{2} \|\mathbf{z} - \hat{\boldsymbol{\theta}}^{(t)}\|_2^2. \quad (14.55)$$

这一步寻找距离暂定值最近的可行点。闭凸集合的欧氏投影唯一, 非凸集合可能存在多解。对半径 $r > 0$ 的范数球 $\mathbf{C} = \{\mathbf{w} : \|\mathbf{w}\|_2 \leq r\}$, 投影为 $\mathbf{w} = \hat{\mathbf{w}} \min(1, r/\|\hat{\mathbf{w}}\|_2)$, 零向量保留。例如 $r = 2$ 时, 暂定参数 $(3, 4)^\top$ 被改为 $(1.2, 1.6)^\top$; 已经在球内的参数不变。这里限制的是更新后的参数, 前面的梯度裁剪限制的是更新前的梯度, 二者不能互换。

矩阵约束也可以直接修正奇异值。对方阵暂定权重 $\hat{\mathbf{W}} = \mathbf{U}\boldsymbol{\Sigma}\mathbf{V}^\top$ 的完整 SVD, 若要求 $\sigma_{\max}(\mathbf{W}) \leq r$, 就把每个奇异值改成 $\min(\sigma_j, r)$; 若要求 $\mathbf{W}^\top \mathbf{W} = \mathbf{I}$, 则取 $\mathbf{W} = \mathbf{U}\mathbf{V}^\top$ 。这两种构造分别是对应集合的 Frobenius 距离投影。例如 $\text{diag}(1.2, 0.6)$ 投影到谱范数不超过 1 的集合, 得到 $\text{diag}(1, 0.6)$; 投影到正交矩阵集合则得到 $\mathbf{I}$, 对较小方向的处理完全不同。

实际训练在每次更新后执行该修正, 并记录参数范数或正交残差。投影提供明确的可行性, 但 SVD 等计算可能昂贵, 且修正后的位移与优化器原先建议的位移不同。动量缓冲、预条件和约束几何怎样配合, 属于算法设计; 保留原缓冲并不等于已经得到几何一致的约束优化方法。

14.4.5.2 用参数化保证每次前向都满足约束

还可以只更新无约束变量 $\mathbf{B}$ ，每次前向由 $\mathbf{B}$ 生成实际权重。正尺度可写成 $\exp(b)$ ，固定非零向量长度可写成 $r\mathbf{v}/\|\mathbf{v}\|_2$ 。对实数方阵，令 $\mathbf{A} = (\mathbf{B} - \mathbf{B}^\top)/2$ ，可用 Cayley 变换

$$\mathbf{W} = (\mathbf{I} - \mathbf{A})(\mathbf{I} + \mathbf{A})^{-1}. \quad (14.56)$$

由于 $\mathbf{A}^\top = -\mathbf{A}$ ，实数情况下 $\mathbf{I} + \mathbf{A}$ 可逆，代数上有 $\mathbf{W}^\top \mathbf{W} = \mathbf{I}$ 。训练将损失梯度穿过该映射传给 $\mathbf{B}$ ，更新的是 $\mathbf{B}$ ，不再要求更新后的 $\mathbf{B}$ 本身正交。实际计算用线性求解实现逆矩阵作用。

这种做法没有“越界后修正”的阶段，但改变了参数坐标并增加映射计算；有限 $\mathbf{A}$ 的上述形式还不能表示含特征值 -1 的全部正交矩阵。所选参数化能覆盖哪些可行权重、求导是否稳定，必须一并检查。浮点计算也会留下小残差，严格的代数性质不意味着数值残差精确为 0。

14.4.5.3 通过惩罚鼓励接近约束

若严格保持正交代价过高，可以在原损失上加 $\lambda\Omega(\mathbf{W})$ ，例如

$$\Omega(\mathbf{W}) = \frac{1}{4}\|\mathbf{W}^\top \mathbf{W} - \mathbf{I}\|_F^2, \quad \nabla_{\mathbf{W}} \Omega = \mathbf{W}(\mathbf{W}^\top \mathbf{W} - \mathbf{I}). \quad (14.57)$$

$\|\cdot\|_F$ 是元素平方和开方的 Frobenius 范数。反向时把 $\lambda\nabla\Omega$ 加入数据损失梯度，再由普通优化器更新；即使 $\Omega > 0$ ，训练也继续。增大 λ 提高违约代价，但可能使目标更难优化，有限系数通常不能保证残差为 0。这是软约束，与每步投影后的硬可行性不同。

实数正交矩阵保持实向量范数，复数酉矩阵（unitary matrix）满足 $\mathbf{W}^* \mathbf{W} = \mathbf{I}$ ，其中 $\mathbf{W}^*$ 为共轭转置。谱上界只控制最大放大，不能保证每个方向都不衰减；正交线性权重也不保证包含激活、门、输入与读出的循环动态具有任意长程记忆。监控约束残差之外，还要检查实际前向尺度与反向梯度。

第二卷“基础、理论和可信性”的“深度学习的可学习性”章“基于参数大小的可学习性”节把网络范数与分类间隔放在同一风险分析中，说明尺度约束也可能影响函数复杂度。不过，本节首先关注传播与可训练性；范数减小是否改善未来风险，还需满足相应数据与间隔条件，第15.3节再讨论其泛化作用。

初始化为训练提供出发点，持续约束改变允许的参数集合，两者应分别说明。约束过强可能排除任务所需变换，约束过弱则未必改善传播；它们与学习率、预条件、归一化和连接共同决定可训练性。

14.5 本章小结

训练改进要对应非凸目标、曲率差异、估计噪声与传播困难。步长、动量和预条件管理更新，归一化改变表示与导数，连接建立传播路径，初始化与持续约束分别管理起点和后续映射。应连同训练误差、达到目标的时间与资源成本评估这些方法；优化改善能否转为更低未来风险，还需要泛化分析与验证。

神经网络的泛化

当网络已经能把训练误差降得很低，模型选择还没有结束。两个网络可能在训练集上同样准确，但对未见过的背景、主体或输入变化给出不同预测。增加训练时间、换一种初始化，或者修改数据增强，都可能改变这种差异。我们需要回答的不只是“网络拟合了多少样本”，还包括“它从样本中保留了什么规律，以及这些规律何时能够用于新数据”。

第二卷的学习理论已经区分经验风险与总体风险，并提供复杂度、稳定性和归纳偏置的分析工具。本章将这些认识放回神经网络的实际学习过程：数据增强改变网络接触的经验，模型结构与显式损失规定可选函数和评价偏好，更新、随机扰动与轨迹选择影响实际学得的解，集成则组合多个已学得的预测。这些方法作用位置不同，适用条件也不同。

记参数为 θ ，训练集为 $S = \{(\mathbf{x}_i, y_i)\}_{i=1}^n$ ，未来样本分布为 P 。经验风险与总体风险分别为

$$\hat{R}_S(\theta) = \frac{1}{n} \sum_{i=1}^n \ell(f_\theta(\mathbf{x}_i), y_i), \quad R_P(\theta) = \mathbb{E}_{(\mathbf{x}, y) \sim P}[\ell(f_\theta(\mathbf{x}), y)]. \quad (15.1)$$

以下方法通常希望降低未来风险，而不只是缩小 $R_P - \hat{R}_S$ ：一个同时在训练和未来数据上很差的常量模型，也可能具有很小的风险差。调节增强强度、正则化系数和停止时刻使用独立验证数据，最终测试数据用于评估已确定的方案。

15.1 主要挑战

第二卷“基础、理论和可信性”的“深度学习的可学习性”章“理论的比较与使用”节分别从参数大小、初始梯度、更新规则和参数分布理解可学习性。这里把实际泛化困难对应到数据是否有代表性、允许哪些函数及算法最终选出哪个解，作为后面方法的选择依据。

15.1.1 数据不足与数据质量

经验风险只约束已经出现的样本，优化器继续降低它也不能补足训练分布缺失的情形。因此，数据覆盖与质量先决定训练目标是否代表未来任务，再决定增强或正则化应处理什么缺口。若识别器只见过某类物体与固定背景同时出现，就可能将背景当作类别线索；这种规则能够降低训练误差，却未必适用于背景变化后的物体。覆盖不足不是单纯的样本总数问题，还涉及类别、环境、主体和时间范围。

标签噪声又使真实规律与标注误差混在一起。独立、近似随机的标注错误与只在某类样本上发生的系统性错误具有不同影响。增加来自同一主体的重复记录，可能扩大名义样本数，却没有提供同等数量的独立信息。第二卷“基础、理论和可信性”的“统计学习框架”章中的独立同分布假设应按真实采样单位检查，不能把相关窗口或复制样本直接当成独立观察。

同分布泛化（in-distribution generalization）考察来自与训练采样相同分布的新样本；**分布变化**（distribution shift）则涉及未来输入、标签机制或二者关系发生改变。前者的风险控制不能自动保证后者的表现。数据增强可以模拟某些已知变化，但不能凭空覆盖未知机制。对于主体相关、时间相关或场景相关数据，应按预期使用条件划分训练、验证和测试，避免共享信息造成过于乐观的评估。

15.1.2 模型容量与归纳偏置

第二卷“基础、理论和可信性”的“深度学习的可学习性”章“神经网络的学习问题”节中的模型族与样本量分析说明，训练拟合能力要连同函数范围理解。共享和范数约束通过改变或偏好这个范围减少自由度，其收益取决于是否保留任务需要的规律。大网络能够表示复杂规律，也可能拟合训练数据中缺乏可迁移意义的细节。**模型容量**（model capacity）描述模型族能够实现多丰富的函数或判别行为；参数数量只是其中一个尺度。权重范数、层间共享、激活、输入分布和学习算法会改变实际可用的函数范围，不能仅由“参数多于样本”判断最终泛化。

归纳偏置（inductive bias）是模型与学习方法倾向于采用哪些规律的先验偏好。卷积倾向复用局部模式，循环共享倾向使用同一状态更新，注意力的可见性和位置表示规定哪些交互可以发生。这些偏好与任务吻合时，可以减少从数据中重新学习结构的负担；与任务不符时，也可能排除需要的规律。

第二卷“基础、理论和可信性”的“深度学习的可学习性”章“基于参数大小的可学习性”节说明了网络范数如何进入某些泛化界。界依赖输入、损失和参数约束，常是充分条件或上界；它不意味着只要把某个范数压低，预测风险就一定降低。容量不足导致拟合偏差，约束过弱则可能保留无关

自由度，实际选择需要在代表性验证数据上比较。

15.1.3 解选择与训练敏感性

第二卷“基础、理论和可信性”的“深度学习的可学习性”章“基于参数梯度更新的可学习性”节说明，相同目标和函数范围仍可因更新规则不同而选出不同解。泛化控制因此还需要关注训练轨迹，而不只修改网络大小或惩罚系数。初始化、样本抽样、训练顺序和优化器决定学习过程到达哪一个参数位置，因而也可能改变未见数据上的预测。**训练敏感性**（training sensitivity）在这里指训练数据或训练随机性的小变化导致所得预测明显变化，不等同于模型对输入扰动的敏感性。

正则化可以排除某些解，提前终止限制进一步拟合，参数平均综合同一轨迹的多个状态，模型集成则组合多个预测。这些方法不必把单模型训练误差继续压低。第二卷“基础、理论和可信性”的“一般学习的可学习性”章“算法稳定性与可学习性”节中的算法稳定性关注更换一个训练样本怎样影响输出损失，它提供了把训练过程与泛化联系起来的途径；某些网络上的经验稳定，并不能替代相应假设下的形式化保证。

15.2 数据增强

当训练数据没有充分展示任务允许的变化时，数据增强把这些变化写入新的经验目标，要求一个参数模型同时解释原样本及相应变换。它通过任务先验约束预测行为，与第15.1.2节的归纳偏置相联系；增加训练视图并不增加同等数量的独立样本。

15.2.1 基于变换的数据增强

变换增强针对已有样本附近的覆盖缺口，将“不应改变答案”或“答案应怎样同步变化”变成损失约束。它改善的是目标覆盖，而非第14.1.2节中损失曲率的必然条件。若任务认为某些输入变化不应改变答案，可以在训练中主动展示这些变化。**数据增强**（data augmentation）按任务约定变换或组合已有样本，以约束网络在相应输入上的预测。设随机变换为 T_ξ ，对应目标变换为 U_ξ ，增强后的目标为

$$\hat{R}_{\text{aug}}(\theta) = \frac{1}{n} \sum_i \mathbb{E}_\xi [\ell(f_\theta(T_\xi(\mathbf{x}_i)), U_\xi(y_i))]. \quad (15.2)$$

分类中的保持标签变换令 $U_\xi(y) = y$ ；分割中移动图像则需同步移动标签，表达输出随输入共同变换的等变关系。增强改变训练分布，而非增加与原始样本独立的新观测。

图像中的平移、裁剪、翻转和颜色调整，时间序列中的时间移位、局部

扰动或伸缩，都需要按语义检查。例如，左右翻转不一定保持方向标签，裁剪可能移除识别对象，颜色变化可能破坏诊断所需信号，时间反转可能改变动作类别。变换名称本身不能证明标签保持不变。

增强强度决定约束覆盖的邻域。太弱时未必带来新的训练条件，太强时可能把样本推到目标定义已不适用的区域。训练时可以随机生成增强，验证时则按照确定的使用条件评估；若采用多次增强预测平均，应作为额外推理过程报告。仅从训练集估计的尺度、字典或变换参数也应保持数据边界，避免利用测试信息。

15.2.2 基于样本混合的数据增强

仅围绕各样本施加局部变换，仍可能让样本之间的预测任意变化。混合增强把插值或区域组合也交给同一个模型拟合，为这些位置规定额外监督关系。**Mixup** 用输入和监督目标的凸组合训练模型。对输入 $\mathbf{x}_i, \mathbf{x}_j$ 及独热类别向量 $\mathbf{y}_i, \mathbf{y}_j$ ，令 $\lambda \sim \text{Beta}(a, a)$ ， $a > 0$ ，构造

$$\tilde{\mathbf{x}} = \lambda \mathbf{x}_i + (1 - \lambda) \mathbf{x}_j, \quad \tilde{\mathbf{y}} = \lambda \mathbf{y}_i + (1 - \lambda) \mathbf{y}_j. \quad (15.3)$$

交叉熵对目标向量线性，因此混合目标的损失等于 $\lambda \ell(f(\tilde{\mathbf{x}}), \mathbf{y}_i) + (1 - \lambda) \ell(f(\tilde{\mathbf{x}}), \mathbf{y}_j)$ 。这鼓励网络在样本之间变化得较为平缓，并将混合比例写进监督；它不声称混合图像是现实中的随机观测¹。

CutMix 从一个样本保留部分区域，用另一个样本的对应区域替换。设二值空间掩码 $\mathbf{M}$ 在保留区域为 1，则 $\tilde{\mathbf{x}} = \mathbf{M} \odot \mathbf{x}_i + (\mathbf{1} - \mathbf{M}) \odot \mathbf{x}_j$ ，目标仍用凸组合，但 λ 取实际保留面积占比。被裁到边界外的区域不应计入替换面积²。

图 15.1 用 2×2 构造输入比较混合方式。**Mixup** 使每个位置叠加，**CutMix** 保留各区域的原始局部值。面积比例是分类监督的近似构造，不保证可见语义证据恰好按面积分配；若目标是逐像素分割，标签应按同一掩码组合，而非统一平均整图标签。

混合强度、样本配对和目标构造应一起检查。若两个样本之间的插值没有任务意义，强行要求线性标签变化可能引入偏差；类别线索集中在很小区域时，面积权重也可能失真。方法的价值来自适当的函数约束，应通过保留原始语义的验证样本判断，而不是把所有混合都视为有效增加数据。

15.3 模型侧的泛化控制

模型侧的控制规定允许哪些计算结构，以及用什么损失评价参数。参数共享与绑定直接缩小可表示的函数集合；范数惩罚保留参数范围，却在目标中增加尺度或稀疏偏好。两者分别对应第 15.1.2 节的归纳偏置与 第二卷

¹ H. Zhang, M. Cisse, Y. N. Dauphin, D. Lopez-Paz, *mixup: Beyond Empirical Risk Minimization* In International Conference on Learning Representations, 2018

² S. Yun, D. Han, S. J. Oh, S. Chun, J. Choe, Y. Yoo, *CutMix: Regularization Strategy to Train Strong Classifiers with Localizable Features* In Proceedings of the IEEE/CVF International Conference on Computer Vision, 2019, pp. 6023–6032




图 15.1 构造的两类 2×2 输入及其混合。样本 A 各位置为 1，目标为 $(1, 0)^T$ ；样本 B 各位置为 0，目标为 $(0, 1)^T$ 。Mixup 取 $\lambda = 0.75$ ，各位置变为 0.75；CutMix 替换右下位置，保留面积也为 0.75。二者目标均为 $(0.75, 0.25)^T$ ，但空间组织不同。这是机制示例，不代表真实图像类别。

“基础、理论和可信性”的“深度学习的可学习性”章“基于参数大小的可学习性”节的复杂度分析。

这里按主要作用位置区分模型侧与训练侧：固定结构及显式损失项放在本节，更新收缩、随机训练扰动和轨迹选择放在第15.4节。方法在数学上可以联系，例如普通 SGD 中的 L2 梯度等价于特定收缩；分类仍需保留“改目标”与“改更新”的区别。

15.3.1 参数共享与参数绑定

第15.1.2节的结构偏置可以直接体现为参数相等关系。共享减少需要分别估计的自由度，让多个位置共同提供梯度，但也把“这些位置适用同一规则”写进函数集合。同一种局部关系出现在多个位置时，分别学习所有参数会浪费样本。**参数共享** (parameter sharing) 让不同计算位置使用同一参数对象。卷积核跨位置复用，循环权重跨时间复用；每次使用都贡献梯度，更新时累积到同一对象。**参数绑定** (weight tying) 则强调多个模块的参数被限制为相等或具有指定对应关系，硬绑定常通过共享实现。

例如，词表嵌入矩阵 $E \in \mathbb{R}^{v \times d}$ 的第 j 行表示词元 j ，输出隐藏状态为 $\mathbf{h} \in \mathbb{R}^d$ 时，可以绑定输出矩阵，令分数 $\mathbf{z} = E\mathbf{h} + \mathbf{b}$ 。这里要求输出隐藏宽度与嵌入宽度相容，输入和输出词表也有一致对应；不相容时需投影或另外定义绑定范围。绑定让同一词元的输入表示与输出判别共享信息，也减少独立参数，但同时施加两种职责可由同一表示承担的假设。

若不希望强制相等，可加入 $\lambda \|\theta_A - \theta_B\|_2^2 / 2$ ，鼓励两组参数接近。有限 λ 下它们仍是两个参数对象，这是一种软约束。共享改变允许的函数结构，软约束改变目标中的偏好；即使参数量减少，也不意味着偏差必然降低。任务在不同位置或模块上需要不同规则时，过强绑定可能妨碍拟合。

15.3.2 参数范数惩罚

若允许的函数太丰富，目标只看训练拟合会留下很多参数选择。范数惩罚用额外代价偏好某些解，对应第二卷“基础、理论和可信性”的“深度学习的可学习性”章“基于参数大小的可学习性”节中的尺度复杂度；具体风险判断仍需连同输入和分类间隔。**范数惩罚**（norm penalty）将学习目标改为

$$\min_{\theta} \hat{R}_S(\theta) + \lambda \Omega(\theta), \quad \lambda \geq 0. \quad (15.4)$$

常见选择为 $\Omega = \|\theta\|_1$ 或 $\Omega = \|\theta\|_2^2/2$ 。严格说，后者是平方范数惩罚；实践中常简称 L2 正则化。它惩罚参数幅度，L1 在 0 附近的非光滑形状则可以促成精确的零参数。

示例 15.1 L1 与 L2 的收缩不同 对标量教学目标 $\frac{1}{2}(w - a)^2$ ，加入 $\lambda w^2/2$ 后，最优解为 $w = a/(1 + \lambda)$ ；加入 $\lambda|w|$ 后，最优解为 $w = \text{sign}(a) \max(|a| - \lambda, 0)$ 。例如 $a = 0.4, \lambda = 0.5$ 时，前者为 $0.4/1.5$ ，后者为 0。这个差异来自惩罚形状，不能据此认为任意普通梯度实现都会精确得到稀疏神经网络。

如果要一起选择或去掉一组参数，可以采用 $\Omega(\theta) = \sum_g \|\theta_g\|_2$ ，其中组 g 可能对应某个特征、神经元或通道，必要时再按组大小加权。组范数对整组是否为 0 产生偏好，与逐参数 L1 的稀疏形态不同。重叠分组和实际模块结构需明确指定，不能只写“采用分组正则化”。

L1 与组范数的零点不可微，近端更新常能更直接处理其非光滑部分；L2 则有梯度 $\lambda\theta$ 。参数尺度还受重参数化影响，例如 ReLU 网络中某层放大、下一层相应缩小可能保留函数但改变参数惩罚。因此，参数范数不是完全独立于表示方式的函数复杂度。选择约束对象、系数及是否包含偏置和归一化参数，都应结合目标检查。

15.4 训练侧的泛化控制

模型族和显式损失确定后，求解过程仍会影响最终预测。训练侧的方法管理何时停止、使用轨迹中的哪个参数、怎样更新，以及训练时施加什么随机扰动。它们联系第二卷“基础、理论和可信性”的“一般学习的可学习性”章“算法稳定性与可学习性”节的训练敏感性与第二卷“基础、理论和可信性”的“深度学习的可学习性”章“基于参数梯度更新的可学习性”节的选解分析，评价重点是验证风险，而非继续压低训练误差。

下面先讨论停止、平均与优化器选择，再讨论权重衰减和随机扰动。权重衰减在更新中收缩参数，因此归入训练侧；Dropout 及噪声按训练时的操作位置归类，也可以从随机计算的期望损失理解。后一联系说明分类并

非互斥的数学定理，但有助于实现时明确该修改发生在哪里。

15.4.1 提前终止

第二卷“基础、理论和可信性”的“一般学习的可学习性”章“凸学习问题的随机梯度下降”小节显示，在相应条件下训练时间和步长总量会进入稳定性分析。提前终止把“沿当前数据训练多久”作为选择变量，用验证表现限制继续拟合，而不是修改每一步的求导公式。持续训练可能继续降低训练误差，但验证表现已经不再改善。**提前终止**（early stopping）根据验证数据选择训练时刻，将训练轨迹上的参数位置当作候选模型。它需要规定评估指标、检查间隔、最小改善量和容忍窗口，并保存出现最佳验证表现时的参数。

例如，每训练一个轮次计算一次验证损失，若连续 p 次检查都没有超过阈值的改善，就停止并恢复已保存的最优参数。恢复参数与使用停止时刻的参数不同；继续训练还需相应恢复优化器和调度状态。随机验证增强、Dropout 未关闭或 BatchNorm 模式错误，都可能让停止判断混入无关噪声。

图 15.2 展示可能出现的曲线形状。真实验证曲线不一定具有单一谷底，短期变差也不证明后面不会改善。容忍窗口是等待与计算预算之间的选择，需要结合噪声、调度和目标，而非固定为普遍常数。




图 15.2 提前终止的示意曲线。训练损失取 $0.05 + 0.7 \exp(-t/15)$ ，验证损失取 $0.16 + 0.5 \exp(-t/12) + 0.002t$ ， t 为训练轮次。虚线标出该构造验证函数的极小点附近，说明继续拟合与验证表现可能分离；这些函数仅用于讲解，不是实验记录。

训练时长限制了算法受训练数据影响的累计程度。在特定光滑、Lipschitz 等条件下，SGD 稳定性界可与步长总量及训练时间联系，第二卷“基础、理论和可信性”的“一般学习的可学习性”章“凸学习问题的随机梯度下降”小节给出了分析；这支持考察训练过程，而不能推出所有深度网络都

越早停止越好³。

验证集被用于选择停止时刻，反复尝试很多策略还可能对验证集过拟合。因此，最终测试应在策略确定后进行；时间序列和持续感知的验证还需模拟实际状态保留和未来信息边界。

15.4.2 参数平均

第14.1.3节中的更新噪声可能使后期参数在附近波动。平均这些位置尝试减弱某个瞬时状态的影响，以一次模型推理综合同一轨迹的信息，但平均后是否仍处在合适损失区域需要检查。**指数移动平均** (exponential moving average, EMA) 维护 $\bar{\theta}^{(t)} = \rho \bar{\theta}^{(t-1)} + (1 - \rho) \theta^{(t)}$, $\rho \in [0, 1)$ 。取初值为训练初始参数或当前参数可以避免零初值的缩小效应， ρ 越大，对近期变化的响应越慢。推理时使用平均参数形成一个模型。

随机权重平均 (stochastic weight averaging, SWA) 选取训练后段的多个参数状态作算术平均。对已收集的 k 个状态，加入新状态 θ 时更新 $\bar{\theta}_{k+1} = k \bar{\theta}_k / (k + 1) + \theta / (k + 1)$ 。原始方案利用较大或周期性学习率采样训练后段区域，平均后若使用 BatchNorm，还需按平均模型重新估计运行统计量⁴。

参数平均与预测平均不同。非线性网络通常不满足 $f_{(\theta_A + \theta_B)/2} = (f_{\theta_A} + f_{\theta_B})/2$ 。对同一训练轨迹附近、坐标含义一致的参数，平均可能仍落在具有良好损失的区域；对独立模型，则可能因隐藏单元的置换或尺度不一致而失败。

示例 15.2 等价网络的参数平均可以失效 取无偏置的两单元 ReLU 网络 $f(x) = \text{ReLU}(x) + \text{ReLU}(-x) = |x|$ 。网络 A 的输入权重为 $(1, -1)$ ，输出权重为 $(1, 1)$ ；网络 B 只交换两个隐藏单元，输入权重为 $(-1, 1)$ ，输出权重仍为 $(1, 1)$ 。两个网络的函数完全相同，但逐坐标平均后的输入权重为 $(0, 0)$ ，输出恒为 0。预测平均仍给出 $|x|$ 。

平均适用性应通过平均参数的实际验证表现判断。EMA 和 SWA 减少了保存全部预测模型的需要，但不保证不增加偏差，也不等同于对独立训练随机性的完整集成。

15.4.3 优化算法的隐式偏置

同一目标可能有多个低损失解，更新方向决定训练倾向哪一个。**隐式偏置** (implicit bias, 前文亦称隐式偏差) 指学习过程在这些解中形成的选择偏好，与小批量梯度是否无偏是不同概念。第二卷“基础、理论和可信性”的“深度学习的可学习性”章“基于参数梯度更新的可学习性”节的线性与矩阵例子说明，这种偏好可以在没有额外惩罚项时出现。

³ M. Hardt, B. Recht, Y. Singer, *Train Faster, Generalize Better: Stability of Stochastic Gradient Descent* In Proceedings of the 33rd International Conference on Machine Learning, 2016, pp. 1225–1234

⁴ P. Izmailov, D. Podoprikin, T. Garipov, D. Vetrov, A. G. Wilson, *Averaging Weights Leads to Wider Optima and Better Generalization* In Proceedings of the 34th Conference on Uncertainty in Artificial Intelligence, 2018, pp. 876–885

可分线性二分类提供一个明确结果：对 $y_i \in \{-1, 1\}$ 、无显式惩罚的逻辑损失，在相应步长与可分条件下，梯度下降使 $\|\mathbf{w}\|_2$ 不断增长，方向趋向欧氏最大间隔分隔方向。损失没有有限范数的零风险极小点，更新过程仍选择了特定方向；其条件与推导见第二卷“基础、理论和可信性”的“深度学习的可学习性”章“基于参数梯度更新的可学习性”节⁵。

示例 15.3 改变更新几何会改变选出的解 用一个训练样本拟合 $w_1 + 2w_2 = 1$ ，目标为 $\frac{1}{2}(w_1 + 2w_2 - 1)^2$ 。从零初始化出发，足够小的固定步长梯度下降始终沿 $(1, 2)^\top$ 移动，收敛到 $(1/5, 2/5)^\top$ ，这是欧氏最小范数解。若改为固定预条件 $\mathbf{P} = \text{diag}(4, 1)$ ，更新始终沿 $(4, 2)^\top$ 移动，则收敛到 $(1/2, 1/4)^\top$ 。两个解的训练误差都为 0，后者最小化的是 $\mathbf{w}^\top \mathbf{P}^{-1} \mathbf{w}$ 。未来数据若需要不同坐标承担不同作用，二者的风险也会不同；仅凭这一个训练约束不能确定哪个偏好正确。

深度网络中的偏好还随参数化、初始化、学习率、批量与训练时长改变，因此实践不是直接宣布某个优化器“泛化最好”。Wilson 等给出了自适应方法与 GD / SGD 选出不同解的构造，并在所研究的网络中观察到自适应方法训练更好而测试更差。这提供了比较非自适应与自适应更新的理由，结论限于相应设置⁶。

Choi 等进一步发现，优化器排名对超参数搜索范围和调节预算敏感。因而把调节充分的 SGD 与默认 Adam 比较，或只比较相同学习率数值，都不足以判断算法的泛化优势。AdamW 还含解耦衰减，比较时需要把更新规则和显式收缩一起说明⁷。

把隐式偏置用于训练选择，可以采用以下可执行的比较过程：

1. 固定网络、数据划分、增强与损失，以带动量 SGD 和 AdamW 作为两种候选。已有训练方案能稳定拟合时，先保留其为基准；更换优化器是检验不同更新几何的一种方式。
2. 分别调节学习率、调度、动量或矩系数，以及适用的衰减系数。给两类候选相当的搜索与训练预算，记录达到目标训练损失的成本和验证表现；不要强制共享同一组数值。
3. 联合阅读训练与验证曲线。训练误差仍高时，先排查第14章的优化困难；训练相近而验证明显不同，才有较明确的选解差异。固定时间预算的表现也应单独报告，因为慢方法可能尚未完成拟合。
4. 对有希望的配置使用多个随机种子复核，再用验证结果选择。停止时刻、批量和参数平均也会改变轨迹，可以分别作控制实验；最终测试集留到方案确定之后。

如果某一配置持续取得更好的验证风险，就在该任务上采用它；目前

⁵ D. Soudry, E. Hoffer, M. S. Nacson, S. Gunasekar, N. Srebro, *The Implicit Bias of Gradient Descent on Separable Data* In Journal of Machine Learning Research, 2018, vol. 19, no. 70, pp. 1–57

⁶ A. C. Wilson, R. Roelofs, M. Stern, N. Srebro, B. Recht, *The Marginal Value of Adaptive Gradient Methods in Machine Learning* In Advances in Neural Information Processing Systems 30, 2017, pp. 4148–4158

⁷ D. Choi, C. J. Shallue, Z. Nado, J. Lee, C. J. Maddison, G. E. Dahl, *On Empirical Comparisons of Optimizers for Deep Learning* In arXiv preprint arXiv:1910.05446, 2020

这些理论与实验没有给出对所有网络都更好的一种优化器。训练中途从 AdamW 切到 SGD 也是新的训练方案，需要重新设置学习率与状态处理并验证，不能默认保留旧矩状态或保证切换后泛化更好。

选解指标本身也要有边界。“平坦极小点泛化更好”需要指定参数坐标与扰动尺度，保持函数不变的重缩放可以改变曲率。使用平坦性评价时，应说明怎样处理这种歧义，不能只凭损失曲面看起来宽就判定未来风险更低⁸。

15.4.4 邻域最坏损失与 SAM

若希望训练点附近的参数扰动也保持较低损失，可以把当前损失替换为指定邻域内的最坏值。**锐度感知最小化**（sharpness-aware minimization, SAM）考虑

$$\min_{\mathbf{w}} \max_{\|\epsilon\|_2 \leq \rho} \mathcal{L}(\mathbf{w} + \epsilon). \quad (15.5)$$

对内层目标在 $\mathbf{w}$ 处作一阶近似且 $\nabla \mathcal{L}(\mathbf{w}) \neq \mathbf{0}$ 时，欧氏球上的近似最大化点为

$$\epsilon^* = \rho \frac{\nabla \mathcal{L}(\mathbf{w})}{\|\nabla \mathcal{L}(\mathbf{w})\|_2}.$$

随后在扰动点计算梯度，却把更新施加到原参数： $\mathbf{w}^+ = \mathbf{w} - \eta \nabla \mathcal{L}(\mathbf{w} + \epsilon^*)$ 。图 15.3 把这两个步骤分开：红箭头寻找邻域内的高损失方向，黄色箭头再降低该处损失。实际小批量实现常用同一批数据完成两次前后向；零梯度、归一化层状态、扰动范数以及参数分组都需要明确约定⁹。




图 15.3 SAM 一次近似更新的几何过程。灰线为教学目标 $L(\mathbf{w}) = (4w_1^2 + w_2^2)/2$ 的等高线，红色虚线是以当前参数为中心、半径 $\rho = 0.45$ 的扰动邻域。红箭头沿当前梯度的一阶近似到达边界高损失点，黄色箭头使用该扰动点的梯度更新原参数。图示解释两次梯度读取的位置，不表示 SAM 必然找到内层精确最大值或必然改善泛化。

SAM 改变的是指定参数坐标和范数下的邻域目标；重参数化会改变同

⁸ L. Dinh, R. Pascanu, S. Bengio, Y. Bengio, *Sharp Minima Can Generalize for Deep Nets* In Proceedings of the 34th International Conference on Machine Learning, 2017, pp. 1019–1028

⁹ P. Foret, A. Kleiner, H. Mobahi, B. Neyshabur, *Sharpness-Aware Minimization for Efficiently Improving Generalization* In International Conference on Learning Representations, 2021

一个函数对应的扰动集合。 ρ 过小会接近普通更新，过大则可能让一阶近似失效或损害拟合。它也不等同于对输入扰动的鲁棒训练，后者改变的是样本空间。是否采用 SAM，应同时比较训练成本、训练损失与独立验证风险，而不能把参数邻域较平直接当成任务泛化的充分条件。

15.4.5 权重衰减

第14.2节把方向、尺度和历史统计分开，参数收缩也可以独立加入更新。权重衰减通过这种算法选择控制尺度；是否等价于某个惩罚目标，要检查预条件和历史缓冲。范数惩罚改变目标，**权重衰减** (weight decay) 直接在更新中收缩参数。对无动量的普通 SGD，L2 惩罚更新为

$$\boldsymbol{\theta}^{(t)} = \boldsymbol{\theta}^{(t-1)} - \eta_t(\mathbf{g}^{(t)} + \lambda \boldsymbol{\theta}^{(t-1)}) = (1 - \eta_t \lambda) \boldsymbol{\theta}^{(t-1)} - \eta_t \mathbf{g}^{(t)}. \quad (15.6)$$

因而在相同参数范围及系数约定下，L2 惩罚与学习率乘以 λ 的收缩等价。若所谓“衰减系数”直接表示每步乘法系数，就还需对应学习率；加入动量也要检查惩罚是否进入动量缓冲，不能不看实现就延用等价结论。

对预条件矩阵 $\mathbf{P}^{(t)}$ ，惩罚项进入梯度后产生 $-\eta_t \lambda \mathbf{P}^{(t)} \boldsymbol{\theta}$ ，而解耦收缩产生 $-\eta_t \lambda \boldsymbol{\theta}$ 。二者通常不同，Adam 中惩罚还可能进入一阶、二阶矩统计。**AdamW** 将衰减从自适应梯度更新中分离，其基本更新为

$$\boldsymbol{\theta}^{(t)} = (1 - \eta_t \lambda) \boldsymbol{\theta}^{(t-1)} - \eta_t \frac{\hat{\mathbf{m}}^{(t)}}{\sqrt{\hat{\mathbf{v}}^{(t)} + \epsilon}}, \quad (15.7)$$

这里矩统计来自数据损失梯度，具体计算见式(14.23)¹⁰。

衰减通过多步乘积发生，学习率调度、更新次数和是否排除部分参数都会改变总收缩量。普通参数坐标下的解耦权重衰减，也不等同于所有预条件坐标中的同一 L2 目标。比较正则化强度时，需要固定更新规则和系数含义。

¹⁰ I. Loshchilov, F. Hutter, *Decoupled Weight Decay Regularization* In International Conference on Learning Representations, 2019

15.4.6 Dropout


当低训练误差依赖一组必须共同出现的中间特征时，可以改变训练时可用的计算路径，要求共享参数在随机子网络中继续预测。Dropout 因此约束受扰动的模型行为，其直接目标不是让单次无扰动损失下降更快。**Dropout** 在训练时随机屏蔽部分激活，使网络在不同的可用特征子集上完成同一任务。设隐藏表示为 $\mathbf{h}$ ，各元素独立保留概率为 $q \in (0, 1]$ ， $m_j \sim \text{Bernoulli}(q)$ 。常见的反向缩放形式为

$$\tilde{h}_j = \frac{m_j}{q} h_j, \quad \mathbb{E}[\tilde{h}_j | \mathbf{h}] = h_j, \quad \text{Var}(\tilde{h}_j | \mathbf{h}) = \frac{1-q}{q} h_j^2. \quad (15.8)$$

训练时除以 q ，常规推理时关闭屏蔽并直接使用 $\mathbf{h}$ 。另一约定在训练时不缩放、推理时乘 q ，两者必须与实现一致。这里 q 为保留率，有些接口使用的是失活率 $1 - q$ ¹¹。

训练目标包含对掩码的期望 $\mathbb{E}_{\mathbf{m}} \ell(f_{\theta, \mathbf{m}}(\mathbf{x}), y)$ 。随机子网络共享参数，它们并不是独立训练的多个模型。保持隐藏表示的期望，也不意味着完整非线性网络的输出满足 $\mathbb{E}_{\mathbf{m}} f_{\theta, \mathbf{m}} = f_{\theta}$ ；因此，单次无掩码推理是某种模型平均的近似，不能当成精确集成公式。

图 15.4 展示同一隐藏层的一个掩码样本。屏蔽后其输入参数仍保留，后续批量可能重新启用，并非永久剪枝。较低 q 增加扰动和方差，也可能损害拟合。BatchNorm 与 Dropout 组合时，还需关注随机激活对运行统计的影响；序列模型中跨时间独立采样或共享掩码，则具有不同扰动结构。



训练: $\tilde{h}_j = m_j h_j / q$ 推理: 使用 h_j $q = 1 - p$

图 15.4 一个三单元隐藏层的构造性 Dropout 示意。中间单元保留浅灰 h_2 轮廓并标出 $m_2 = 0$ ，说明它只是本批被屏蔽，而非永久删除；灰色虚线为本次不参与前向计算的路径。底部公式带明确区分保留概率 $q = 1 - p$ 与丢弃概率 p ，并给出 inverted Dropout 在训练时除以 q 、推理时无需再缩放的约定。

15.4.7 结构化随机失活

随机扰动应覆盖模型真正依赖的信息单位；若重复线索能从邻近位置轻易补回，逐元素屏蔽施加的约束就较弱。结构化随机失活根据网络结构选择连接、通道、空间块或整层作为屏蔽对象，与第14.4节的结构组织相对应，而非只提高逐元素失活概率。

DropConnect 对权重连接采样掩码，令 $\tilde{\mathbf{W}} = \mathbf{M} \odot \mathbf{W}$ ，随后再计算激活；Dropout 则直接作用于激活。基本训练与推理的缩放、分布近似应按各自

¹¹ N. Srivastava, G. Hinton, A. Krizhevsky, I. Sutskever, R. Salakhutdinov, *Dropout: A Simple Way to Prevent Neural Networks from Overfitting* In Journal of Machine Learning Research, 2014, vol. 15, no. 56, pp. 1929–1958

约定处理，两种失活的随机函数不相同¹²。

空间 Dropout (spatial dropout) 在一个通道的所有空间位置使用同一掩码，削弱网络对某个整通道特征的依赖。**DropBlock** 随机屏蔽特征图中连续的空间块，干扰局部邻域可提供的重复信息。块大小、采样位置和边界会影响实际失活率，不能仅把块中心采样概率当作元素失活概率¹³。

随机深度 (stochastic depth) 对残差分支随机启用或绕过，让训练时经过的有效深度变化。一个期望保持的实现写为 $\mathbf{h}^{(l+1)} = \mathbf{h}^{(l)} + (m_l/q_l)F_l(\mathbf{h}^{(l)})$, $m_l \sim \text{Bernoulli}(q_l)$ ，推理时使用全部分支。原始方法也可将缩放放在推理阶段；是否真正跳过被屏蔽分支的计算影响训练时间¹⁴。

连接、通道、空间块和整层对应不同的信息粒度。屏蔽过大可能毁掉任务所需信息，特别是对对象很小、通道很窄或缺少恒等路径时。失活应与结构匹配，并报告保留概率、作用位置及采样共享范围。

15.4.8 噪声注入

第二卷“基础、理论和可信性”的“深度学习的可学习性”章“基于参数分布的可学习性”节把参数分布及其期望损失纳入分析；噪声训练也可以看成在规定扰动分布下优化平均表现。其作用由注入位置和协方差决定，不能只凭“加入随机性”推断泛化改善。随机扰动还可以连续改变表示或参数，而非只选择保留与屏蔽。**噪声注入** (noise injection) 在训练中使用 $\tilde{\mathbf{h}} = \mathbf{h} + \epsilon$ 或 $\tilde{\theta} = \theta + \epsilon$ ，其中噪声的均值、协方差和采样范围需要明确。输入噪声属于数据增强的一种，中间表示噪声改变后续计算，参数噪声则同时影响所有使用该参数的位置。

对足够光滑的目标函数和小幅零均值噪声，二阶展开给出局部近似

$$\mathbb{E}_\epsilon[\mathcal{L}(\theta + \epsilon)] \approx \mathcal{L}(\theta) + \frac{1}{2} \text{tr}(\Sigma \nabla^2 \mathcal{L}(\theta)), \quad (15.9)$$

其中 $\Sigma = \mathbb{E}[\epsilon\epsilon^\top]$ 。近似的余项需要噪声幅度与光滑条件控制；二阶项未必非负，所以不能把任意非凸目标上的噪声都解释为固定的正范数惩罚。

一个可精确核查的特殊情况是线性回归。对预测 $\mathbf{w}^\top \mathbf{x}$ 、平方损失及输入噪声 $\mathbb{E}\epsilon = \mathbf{0}$ 、 $\mathbb{E}\epsilon\epsilon^\top = \sigma^2 \mathbf{I}$ ，有

$$\mathbb{E} \frac{1}{2} [\mathbf{y} - \mathbf{w}^\top (\mathbf{x} + \epsilon)]^2 = \frac{1}{2} (\mathbf{y} - \mathbf{w}^\top \mathbf{x})^2 + \frac{\sigma^2}{2} \|\mathbf{w}\|_2^2. \quad (15.10)$$

零均值消去交叉项，协方差决定额外二次项。这说明噪声与正则化的联系取决于损失、模型和注入位置；非线性网络中的输入噪声通常不能直接化为所有参数的 L2 惩罚。

Dropout 也可理解为一种乘性噪声： $\tilde{h}_j = h_j + [m_j/q - 1]h_j$ ，条件均值为 0、方差与 h_j^2 成比例。它与加性高斯噪声的分布和尺度不同。噪声是否

¹² L. Wan, M. Zeiler, S. Zhang, Y. Le Cun, R. Fergus, *Regularization of Neural Networks Using Drop-Connect* In Proceedings of the 30th International Conference on Machine Learning, 2013, pp. 1058–1066

¹³ G. Ghiasi, T.-Y. Lin, Q. V. Le, *DropBlock: A Regularization Method for Convolutional Networks* In Advances in Neural Information Processing Systems 31, 2018, pp. 10727–10737

¹⁴ G. Huang, Y. Sun, Z. Liu, D. Sedra, K. Q. Weinberger, *Deep Networks with Stochastic Depth* In Proceedings of the European Conference on Computer Vision, 2016, pp. 646–661

符合任务中合理的变化，决定了对局部邻域的约束是否有意义；它不能修复系统性错误标签或数据泄漏。

15.5 模型集成

若不同训练过程保留了不同预测误差，可以通过组合预测减少其中部分波动。这个机制与第15.1.3节的解差异相连；收益取决于成员质量与误差相关性，而不是单纯增加模型数。

15.5.1 装袋法 (Bagging)

第6.2.1节已介绍**装袋法** (bootstrap aggregating, Bagging)：对训练集作多次自助重采样，分别训练成员，再按固定规则组合预测。它围绕训练样本变化生成多个解，用预测组合减弱单次采样的影响，针对的是学习过程的抽样敏感性，与第二卷“基础、理论和可信性”的“一般学习的可学习性”章“算法稳定性与可学习性”节关注的问题相邻，不过重采样平均本身不是该稳定性定理的证明。用神经网络作为成员时，仍需保持相同的输出语义：回归平均数值预测，分类可平均类别概率或投票；概率平均通常不等于先平均分数再做 Softmax。组合规则见第6.1.2节¹⁵。

重采样的覆盖率和袋外预测分别由式(6.4)与式(6.5)说明。神经网络的超参数和成员选择同样需要保持评估边界；相关数据应按主体或时间块重采样，逐行抽样不能模拟独立主体变化。

集成收益还取决于成员之间共享多少波动。式(6.2)在固定输入、等方差和等相关条件下，描述标量预测平均的方差，随机性来自训练集抽取、重采样及训练过程。共同波动和偏差不会因增加成员自动消失；这也不是分类零一风险公式，不能从预测方差下降直接推出分类错误率下降。

15.5.2 基于训练随机性的集成

第15.1.3节中，初始化与数据次序即使在同一训练集上也能改变所得解。因此，也可以让所有网络使用同一训练集，通过不同初始化、数据顺序、增强和随机失活形成不同预测函数。与装袋法的数据组织不同，这类集成不要求对原始样本进行有放回重采样，也不自然提供相同的袋外集合。

成员的质量与差异需要一起考虑。加入一个在关键输入上系统性错误的模型，未必改善平均；只改变随机种子但各模型预测几乎一致，也可能收效有限。应在同一验证集上考察单模型表现与预测分歧，并固定组合权重；不能通过查看最终测试结果反复筛选成员。

集成通常增加训练和推理成本。 M 个相同规模网络若顺序运行，模型计算量约为单个的 M 倍；并行运行可以降低部分等待时间，却需要更多设备或存储。第15.4.2节的参数平均形成一个模型，预测集成则保留多个

¹⁵ L. Breiman, *Bagging Predictors* In *Machine Learning*, 1996, vol. 24, no. 2, pp. 123–140

模型；二者不仅部署成本不同，所得函数一般也不同。选择成员数与组合方式时，任务质量、延迟和资源预算都应进入判断。

15.6 本章小结

低训练误差不能单独说明网络学得了可迁移规律。未来风险受到数据覆盖与质量、模型归纳偏置和训练解选择共同影响。同分布评估、场景变化和持续状态的边界不同，数据划分必须对应预期使用方式。

增强把任务允许的变化写进经验目标，参数共享与范数惩罚引入结构和尺度偏好，权重衰减通过更新收缩参数，随机失活与噪声约束受扰动的计算，停止时刻和参数平均改变轨迹上的解选择，集成则利用多个预测的差异。它们可以组合，但不具有无条件的收益：错误增强会改变语义，过强约束会损害拟合，不对齐的参数平均会破坏函数，高度相关的模型也难以从集成获益。将这些机制与复杂度、稳定性和隐式偏置联系起来，既有助于解释观察，也要求保留各自的条件；最终选择仍应由符合使用场景的验证和独立测试支持。

第三部分

概率图模型

Probabilistic Graphical Models

概率图模型概述

一台设备发出报警，是否应当立即停机？报警可能来自设备故障造成的过热，也可能来自传感器失灵。只输出“有故障”或“无故障”，无法说明另一个结果还有多大可能，也无法回答新增证据会怎样改变判断。即使分类结果相同，故障概率为 0.02 和 0.45 时，维修人员面对的风险也很不同。

要回答这类问题，需要描述多个不确定因素怎样共同变化。**概率图模型** (probabilistic graphical model, PGM) 用图组织随机变量之间的局部依赖，再用局部概率函数组成联合分布。图使模型不必为所有变量组合分别指定概率，也让后续计算能够利用局部结构。本章只建立后续章节共同需要的概念：为什么要建模分布，图模型怎样表示联合分布，以及推断和学习分别解决什么问题。

16.1 从单值预测到结构化分布

熟悉的预测形式是 $\hat{y} = f(x)$ ：给定输入 x ，模型返回一个数值或类别。例如，以传感器读数为输入，输出设备下一时刻的温度。这种**点预测** (point prediction) 把结果压缩成一个值，适合直接给出答案，却不保留其他结果的可能性。

预测分布 (predictive distribution) $p(y | x)$ 描述输入固定后，不同输出有多大可能。对于离散输出，它为每种结果分配概率；对于连续输出，它给出概率密度，区间概率由积分得到。分布不仅告诉我们结果集中在哪里，还能表示多个彼此分离的高概率区域。

图 16.1 给出一个人工构造的温度预测。冷却系统可能处于两种工况，预测密度分别集中在 40°C 和 80°C 附近，权重各为一半。均值 60°C 位于两个峰之间，并不是高概率区域。若只保留均值，就看不见高温工况；若只保留一个峰，又会丢掉另一种工况。这里的分布为教学设定，不是实际设备的测量结果。

点预测和分布预测并不冲突。得到预测分布以后，仍可根据任务选择均值、概率最大的结果或其他行动。区别在于，分布先保留不确定性，点预




图 16.1 同一个双峰预测分布可以产生均值为 60°C 的点预测。实线为两个等权高斯密度的混合，每个分量的标准差为 3°C ；虚线标出均值。点预测没有保留两个高概率区域的位置。

测再按照使用目的把它压缩成一个结果。

困难在于，多个变量的联合分布会迅速变大。若有 d 个二值变量，完整联合表包含 2^d 个状态，需要 $2^d - 1$ 个自由参数。变量增多以后，有限数据很难覆盖所有组合，计算一个变量的边缘概率也可能需要汇总大量状态。概率图模型并没有取消这些困难，而是试图利用可信的局部依赖减少需要表示和计算的内容。

最强的简化是假设所有变量相互独立，但这会删掉故障与报警之间真正有用的联系。更合适的做法是只删除在特定条件下已经多余的依赖。例如，设备是否报警可以依赖是否过热和传感器是否失灵；一旦这两个状态已经给定，故障状态不必再直接进入报警的局部概率。这样的局部假设正是图结构要记录的信息。

16.2 图模型上的表示

本章使用四个二值随机变量： F 表示设备故障， H 表示过热， A 表示报警， S 表示传感器失灵，值 1 表示相应事件发生，值 0 表示未发生。联合概率 $p(f, h, a, s)$ 描述四个变量同时取给定值的可能性，其中小写字母表示对应随机变量的取值。

后续章节会在有向图、因子图、团树和缺失数据图中反复使用相近符号。图 16.2 集中列出本部分的默认视觉约定，使读者可以先辨认对象类型，再阅读具体连接。虚线的作用最依赖上下文，因此每幅图仍会在图内或图注中说明它表示辅助对应、证据读入还是分隔边界。

从联合分布中只保留一部分变量，需要把其余变量的可能取值汇总起来。对离散变量，这种**边缘化**（marginalization）通过求和完成；获得证




图 16.2 概率图模型部分的视觉约定。空心、填充和实点区分潜变量、观测变量与给定量；方框表示局部因子，金色强调团树分隔集或共享接口，红色表示非法或需警示的对象。实线箭头的概率语义与计算流语义由所在图决定；虚线只作辅助表达，不应在没有图注时自动解释为概率依赖。具体图内标注优先于本总图。

据后重新比较各种可能性，则使用条件概率。例如

$$p(f, a) = \sum_{h, s} p(f, h, a, s), \quad p(f | a) = \frac{p(f, a)}{p(a)}, \quad p(a) > 0. \quad (16.1)$$

这里对 h, s 求和，表示不把未知状态硬填成某个值，而是保留它们的所有可能性。连续变量采用相应的积分。

如果无论 X 取什么值， Y 的分布都不改变，就称 X 与 Y 独立。更常用的是**条件独立**（conditional independence）：给定 Z 以后，继续观察 Y 不再改变对 X 的判断，记为 $X \perp Y | Z$ 。在离散情形，它可以写成

$$p(x, y | z) = p(x | z)p(y | z), \quad p(z) > 0. \quad (16.2)$$

条件独立不是说 X 与 Y 永远没有关系，而是说 Z 已经包含了当前问题中连接它们所需的信息。概率图模型正是利用这类局部假设压缩联合分布。

在设备例子中，假设故障 F 与传感器失灵 S 独立，过热 H 只直接依赖故障，报警 A 只直接依赖过热和传感器状态。联合分布便可以写成

$$p(f, h, a, s) = p(f)p(s)p(h | f)p(a | h, s). \quad (16.3)$$

只要每个局部条件分布本身合法，这四个函数的乘积就定义了完整联合分布。对二值变量，两个根变量各需一个参数，过热条件分布需要两个，报警条件分布需要四个，总共 8 个自由参数，少于完整联合表的 15 个。减少的参数来自局部依赖假设，而不是记号上的省略。

把每个随机变量画成节点，并用箭头表示“哪个变量进入哪个局部条件分布”，就得到图 16.3。例如 $H \rightarrow A \leftarrow S$ 对应局部项 $p(a | h, s)$ 。箭头在这里记录概率分解，不凭图形本身断言因果关系。




图 16.3 设备诊断模型。节点表示随机变量，箭头指向局部条件分布所描述的变量，例如 $H \rightarrow A \leftarrow S$ 对应 $p(a | h, s)$ 。箭头指定概率分解，不自动具有因果含义。

图只说明局部依赖结构，还需要局部概率函数给出具体数值。反过来，一组数值表若没有说明各表对应哪些变量，也不足以解释整个模型。理解概率图模型时，应同时分清图结构和组成联合分布的局部函数：前者记录依赖怎样组织，后者决定模型实际给出什么概率。

图模型最基本的概率表示有两类。**有向图模型** (directed graphical model) 像设备模型一样，用箭头组织局部条件分布；后续第 17 章将说明怎样从有向图读取条件独立关系。**无向图模型** (undirected graphical model) 用无向边表示对称的局部相互作用，再将一组非负局部函数的乘积归一化为概率分布；第 18 章将展开这种表示。

因子图 (factor graph) 关注的是局部乘积本身。它把随机变量和局部函数画成两类节点，并在变量属于某个函数的输入时连边。因子图可以表示有向模型的条件概率乘积，也可以表示无向模型的局部函数乘积，因此它是组织计算的表示方式，不是与有向图、无向图互斥的第三类概率语义。第 19 章将比较三种表示保留的信息。

16.3 图模型上的推断与学习

图结构和局部概率确定以后，模型仍需经过计算才能回答具体问题。**概率推断** (probabilistic inference) 是在模型已知时，根据已有证据计算所需概率。要回答“报警后设备故障的概率是多少”，需要计算 $p(F = 1 | A = 1)$ ；由于过热 H 和传感器状态 S 没有被观测，计算时必须汇总它们的所有可能取值。

把设备模型扩展到更多部件。扩展后共有 30 个未观测的二值状态，其中包括原来的过热 H 、传感器状态 S 和新增的部件状态或运行状态；以下将这 30 个未观测状态统一记为 $\mathbf{Z} = (Z_1, \dots, Z_{30})$ 。报警 $A = 1$ 仍是证据，故障 F 仍是查询目标。后验需要把这些变量的每一种配置都纳入比较：

$$p(F = 1 | A = 1) = \frac{\sum_{\mathbf{z} \in \{0,1\}^{30}} p(F = 1, A = 1, \mathbf{z})}{\sum_{f \in \{0,1\}} \sum_{\mathbf{z} \in \{0,1\}^{30}} p(f, A = 1, \mathbf{z})}. \quad (16.4)$$

若直接展开，分子要汇总 2^{30} 个未观测状态配置，约为 10.7 亿项；分母还要同时遍历故障的两个取值，共有 2^{31} 个完整配置项，约为 21.5 亿项。这里的项数表示求和中需要纳入多少种状态组合，不是模型必须具有同样多的参数。

局部因子使单个完整配置 $p(f, A = 1, \mathbf{z})$ 通常容易评价：只需查出或计算该配置涉及的局部概率，再将它们相乘。但后验不是某个完整配置的概率，而是对大量未观测状态配置的汇总。因而，“单个完整配置易评价”和“汇总全部未观测状态仍昂贵”可以同时成立。图中的局部结构有时能够复用计算，但能节省多少取决于依赖怎样连接；具体算法与结构条件留到后续章节。

精确推断 (exact inference) 要求在给定模型下得到原查询的准确答案。它适合结构允许有效计算、或问题规模较小的情形；结构复杂时，中间计算仍可能非常大。**近似推断** (approximate inference) 则在无法承担精确计算时，接受一定误差，以换取时间或空间上的可行性。第 20 章至第 23 章将分别展开精确与近似推断，本章不提前介绍具体实现路线。

模型中的局部概率通常不是预先知道的，还需要从数据获得。**参数学习** (parameter learning) 在图结构和局部函数形式已经确定时，估计这些函数中的数值。例如，若记录了许多设备的故障和过热状态，就可以估计 $p(H = 1 | F = 1)$ 。数据越少、状态越稀有，估计通常越不稳定；数据中存在缺失或未观测变量时，所需计数也无法直接得到。

如果连哪些变量应直接相连也不确定，就需要**结构学习** (structure learning) 根据数据和领域约束选择图。结构过于简单可能遗漏重要依赖，结构过于复杂则通常需要更多数据并增加计算负担。学习到有向边也不自动等于发现因果方向；因果解释需要额外假设和证据。

推断与学习解决的是不同问题：推断固定模型、计算未知状态；学习固定数据、确定模型结构或参数。当数据含有未观测变量时，两者会互相依赖，因为学习参数之前，往往要先用当前模型推断这些变量可能取什么值。第 24 和第 25 章将分别展开参数与结构学习。

16.4 概率图模型的演进

概率图模型并不是一套方法按年份依次替代另一套方法的结果。图 16.4 从现代视角出发，按照本书关心的问题将相关工作归纳为五条相互衔接、但至今仍并存的线索。这种组织方式用于说明不同模型和技术回应了哪些问题、留下了什么边界，并非逐项复原原作者的提出动机。

当完整轨迹或整体状态空间很大时，可以用局部规律描述相邻时刻或相邻位置的依赖。沿着**局部随机过程** (local stochastic process) 这条线索，Markov 性质用当前状态概括与未来有关的历史，格点模型则用邻域相互



图 16.4 按本书问题线索组织的概率图模型现代回顾。五个阶段依次标出局部随机过程、图结构语义、精确推断、学习与近似，以及神经参数化中的代表方法；上方主线表示问题范围逐步扩展，不表示后出现的技术取代了此前方法。各阶段仍受表示假设、树宽、估计误差或推断代价等条件约束。

作用描述整体配置；Ising 模型是后一类模型的早期代表。局部性减少了必须直接指定的关系，却还没有给出后来概率图模型中统一的图分离语义，也不保证所有全局概率都容易计算¹。

第二条线索是怎样明确表示“哪些变量直接相关、给定什么以后哪些信息变得多余”。**图结构语义**（graph-structured semantics）把条件独立、局部概率分解和图上的分离规则联系起来；有向网络与无向网络由此成为组织复杂联合分布的两种基本方式。Pearl 对有向概率网络的系统化处理以及 Lauritzen 对图模型理论的整理，确立了这一表示框架。图能编码概率约束，但有向边本身不自动获得因果含义，特殊参数也可能产生图中没有表达的额外独立性²。

第三条线索关注怎样由局部函数得到边缘概率和后验。**精确推断**（exact inference）中，变量消除通过重排求和减少重复计算，树上的置信传播和一般图上的团树则把中间结果组织成可复用的局部消息；Lauritzen 与 Spiegelhalter 将图变换和局部概率计算结合为适用于一般网络的系统方法。精确推断没有消除组合爆炸：对离散表格而言，中间团的状态空间随树宽指数增长，高树宽模型仍可能无法承受³。

第四条线索关注模型参数或图结构未知、记录不完整、精确后验不可承受时，怎样从数据估计模型并在预算内近似查询。**学习与近似推断**（learning and approximate inference）中，参数学习估计局部函数，结构学习选择依赖连接；存在缺失或潜变量时，期望最大化（expectation-maximization, EM）等方法交替计算后验统计量和更新参数，变分方法和采样方法则以优化误差或随机误差换取可计算性。这些路线分别受到组合搜索与可识别性、局部最优、近似族或有限样本波动的限制，不是对精确推断的无条件替代⁴。

第五条线索关注怎样表达图像、文本等高维数据中的复杂局部关系。**神经参数化**（neural parameterization）用神经网络表示局部条件分布、势函数或近似后验；VAE 将神经生成模型与可学习的近似后验结合，规范化流

¹ E. Ising, *Beitrag zur Theorie des Ferromagnetismus* In Zeitschrift für Physik, 1925, vol. 31, pp. 253–258

² J. Pearl, *Probabilistic Reasoning in Intelligent Systems: Networks of Plausible Inference*, Morgan Kaufmann, 1988; S. L. Lauritzen, *Graphical Models*, Clarendon Press, 1996

³ S. L. Lauritzen, D. J. Spiegelhalter, *Local Computations with Probabilities on Graphical Structures and Their Application to Expert Systems* In Journal of the Royal Statistical Society: Series B (Methodological), 1988, vol. 50, no. 2, pp. 157–194; D. Koller, N. Friedman, *Probabilistic Graphical Models: Principles and Techniques*, MIT Press, 2009

⁴ A. P. Dempster, N. M. Laird, D. B. Rubin, *Maximum Likelihood from Incomplete Data via the EM Algorithm* In Journal of the Royal Statistical Society: Series B (Methodological), 1977, vol. 39, no. 1, pp. 1–22; M. J. Wainwright, M. I. Jordan, *Graphical Models, Exponential Families, and Variational Inference* In Foundations and Trends in Machine Learning, 2008, vol. 1, no. 1–2, pp. 1–305; D.

用可逆神经变换构造可评价密度或增强近似后验, 扩散模型则学习逐步逆转人为噪声过程。表达能力提高以后, 归一化、似然评价以及推断或采样代价仍需分别处理⁵。

16.5 本章小结

点预测给出一个结果, 概率分布则保留其他结果的可能性。多个变量的联合分布会随变量数量迅速增大, 概率图模型因此用局部条件独立组织依赖, 再由局部概率函数组成联合分布。图结构减少了需要明确指定的关系, 但这种简化是否成立, 取决于局部假设是否符合问题。

图模型上的表示以有向图和无向图为两种基本概率语义, 因子图则把两类模型中的局部乘积显式画出来。局部因子可以让单个完整配置易于评价, 却不保证汇总大量未观测状态配置同样容易。模型给定后, 推断根据证据回答概率查询; 数据给定后, 学习估计参数或选择结构。

表示、计算和学习上的困难共同推动了概率图模型的演进: 局部随机规律压缩依赖, 图结构赋予这些依赖可检查的语义, 精确推断重组全局计算, 学习与近似推断处理未知模型和不可承受的查询, 神经参数化再扩展局部函数的表达能力。这些路线各有边界, 没有按时代相互取代。下一章将从有向图出发, 严格说明图结构、条件独立和联合分解怎样联系起来。

⁵ D. P. Kingma, M. Welling, *Auto-Encoding Variational Bayes* In arXiv preprint arXiv:1312.6114, 2013; D. Rezende, S. Mohamed, *Variational Inference with Normalizing Flows* In Proceedings of the 32nd International Conference on Machine Learning, 2015, pp. 1530–1538; J. Sohl-Dickstein, E. Weiss, N. Maheswaranathan, S. Ganguli, *Deep Unsupervised Learning using Nonequilibrium Thermodynamics* In Proceedings of the 32nd International Conference on Machine Learning, 2015, pp. 2256–2265


有向图模型

设备报警以后，故障的可能性通常会上升；但若随后发现报警传感器已经失灵，对故障的怀疑又可能减弱。同样是增加一条观测，为什么有时可以隔断变量之间的联系，有时反而会建立联系？回答这个问题，需要同时说明图上的箭头约定了哪些概率关系，以及这些关系在条件化以后怎样改变。

本章沿用第 16 章的设备故障问题，但把建模假设写得更精确。图规定一个变量在给定哪些变量以后，可以不再依赖其余已出现的变量；局部与全局独立性分别考察一个节点的邻域和连接两组节点的所有路径；因子分解则把这些独立性变为联合分布的乘积表示，局部参数化进一步说明怎样用条件概率表或连续条件分布记录每个因子。这里以一个固定顺序下的独立性假设定义模型，陈述它与乘积分解描述同一模型类的结论；全局性质蕴含局部性质的证明随命题给出，其余跨表示证明集中放在第 19.2.3 节。

17.1 有向图模型的定义

设设备有四个二值随机变量： F 表示故障， H 表示过热， A 表示报警， S 表示传感器失灵，取值 1 表示相应状态出现。图 17.1 只保留 $F \rightarrow H \rightarrow A \leftarrow S$ 三条箭头。这个选择表达一种简化：预测过热时只使用故障状态，预测报警时只使用过热和传感器状态。它是用于讲解的人工模型，并不是从真实设备统计中验证得到的结构。



拓扑序一： F, S, H, A

拓扑序二： S, F, H, A

图 17.1 设备故障的有向图。箭头给出局部条件分布允许使用的输入； F 与 S 是没有父节点的根节点。下方列出两个合法拓扑序，它们改变书写顺序，但没有改变图。

为准确描述这种结构，称 $\mathcal{G} = (V, E)$ 为**有向图** (directed graph)，其中 V 是有限节点集合， E 由有序节点对组成； $(i, j) \in E$ 写作 $i \rightarrow j$ 。一条**有向路径** (directed path) 沿着箭头依次前进，例如 $F \rightarrow H \rightarrow A$ 。若沿箭头走若干步能回到出发节点，就形成有向环。不含任何有向环的图称为**有向无环图** (directed acyclic graph)：依赖关系不能沿箭头绕回自身。本部分如无特殊说明，“有向图”均指没有有向环的图；讨论有环情形时会单独指出。本章不允许自环。

对节点 i ，直接指向它的节点组成**父节点** (parent) 集合 $\text{pa}(i)$ ，它直接指向的节点组成**子节点** (child) 集合 $\text{ch}(i)$ 。沿一条长度至少为一的有向路径能够到达 i 的节点称为其**祖先** (ancestor)，记为 $\text{an}(i)$ ；从 i 沿这样的路径可达的节点称为其**后代** (descendant)，记为 $\text{de}(i)$ 。这两个集合都不含 i 本身。例如， $\text{pa}(A) = \{H, S\}$ 、 $\text{an}(A) = \{F, H, S\}$ ，而 $\text{de}(S) = \{A\}$ 。例子中用变量名同时标记对应的节点；一般公式仍区分节点集合 $A \subseteq V$ 与随机向量 $\mathbf{X}_A$ 。

要按顺序指定变量的条件分布，必须保证所需的父节点已经出现。**拓扑序** (topological order) 就是让每条箭头都从排在前面的节点指向后面的节点的排列。每个有限有向图都至少存在一个拓扑序，但不一定唯一；图 17.1 中的 F, S, H, A 和 S, F, H, A 都合法。

现在固定一个拓扑序，并按该顺序将节点重新标记为 $1, \dots, d$ 。节点 i 的**前驱集合** (predecessor set) 是 $\text{pre}(i) = \{1, \dots, i-1\}$ ，即在这个固定排列中已经出现的所有节点。父节点必属于前驱，但前驱未必是祖先；两个没有任何路径相连的节点也可以一前一后出现。图的概率假设需要区分“先出现”和“直接作为输入”。

定义 17.1 有序 Markov 假设与有向图模型 给定有向图 $\mathcal{G}$ 及一个固定拓扑序，若联合分布 p 对每个 $i \in V$ 满足

$$X_i \perp \mathbf{X}_{\text{pre}(i) \setminus \text{pa}(i)} \mid \mathbf{X}_{\text{pa}(i)}, \quad (17.1)$$

则称它满足该顺序下的**有序 Markov 假设** (ordered Markov assumption)。**有向图模型** (directed graphical model) 是有向图及其节点随机变量的联合分布，其中该联合分布满足上述假设。文献中传统上也称这类模型为**贝叶斯网络** (Bayesian network)；本书统一使用“有向图模型”。

式 (17.1) 的意思是：父节点的取值一旦给定，其余前驱不再提供预测 X_i 所需的信息。这是对条件分布的限制，不只是均值不变或相关系数为零。根节点的父集为空，条件化随之省去；前驱也为空时，独立性陈述没

有额外内容。对固定顺序 F, S, H, A ，非平凡假设具体为

$$S \perp F, \quad H \perp S \mid F, \quad A \perp F \mid (H, S).$$

单凭这个定义，不能不加论证地换一个拓扑序再调用新的有序假设。只有结合有序性质与因子分解的等价关系，才能推出模型类与所选合法拓扑序无关；完整证明见第 19.2.3 节。

本章用 p 同时表示离散概率质量函数和连续密度。密度需要说明按什么方式积分：离散状态采用计数测度，积分就是求和；实数坐标通常采用 Lebesgue 测度，积分按长度计算。联合密度则相对于各坐标基准测度的乘积定义，例如两个实数坐标上的乘积测度按面积计算。

离散情形中，条件分布只在条件事件具有正概率时由联合分布唯一确定；在零质量条件配置上可以任取归一化版本，不能把不存在的条件概率比值当成已定义的数。连续情形假定存在上述联合密度；条件密度等式按条件变量的边缘分布几乎处处理解，即允许忽略该边缘分布下概率为零的集合，不同条件分布版本只能在这些集合上修改。后文证明以有限离散变量的求和写出，密度情形将求和换为积分；非负因子允许按 Tonelli 定理交换积分次序。本章不要求联合分布严格为正。

有向边表示局部条件分布中允许存在的直接概率依赖，不保证某个特定参数下这种依赖一定非零。箭头也不自动表示因果：用 F 预测 H 的分布，与主动改变 F 会如何改变 H ，是不同问题。因果解释需要额外建模假设，第 25 章再讨论这些假设和识别边界。

17.2 有向图的局部独立性

前驱集合依赖排列，图上还存在一个不依赖排列的对象：节点的非后代。记

$$\text{nd}(i) = V \setminus (\{i\} \cup \text{de}(i)).$$

该集合不含节点自身，但包含父节点。一个节点的父节点不能是它的后代，否则会出现有向环。

定义 17.2 局部 Markov 性质 分布 p 满足有向图 $\mathcal{G}$ 的**局部 Markov 性质** (local Markov property)，是指对每个节点 i ,

$$X_i \perp \mathbf{X}_{\text{nd}(i) \setminus \text{pa}(i)} \mid \mathbf{X}_{\text{pa}(i)}. \quad (17.2)$$

这条性质说，给定父节点后，只要另一个节点不是后代，它就不能再提供关于 X_i 的信息。它没有声称父节点能屏蔽后代：设备故障模型中，知道 F 并不能使 H 与报警 A 独立，因为报警仍提供关于过热的观测线索。

任何合法拓扑序的前驱都是非后代。因此，局部性质通过删去独立性陈述中不需要的变量，可以推出固定顺序下的有序性质；反向却不能仅靠集合包含关系得到。例如，顺序 F, S, H, A 中， S 的有序性质只写出 $S \perp F$ ，局部性质则写出 $S \perp (F, H)$ 。后者还包含排在 S 之后、但不是 S 后代的 H 。从因子分解推出更大的非后代集合需要祖先边缘化，证明见第 19.2.3 节。

若问题变为“给定哪些变量，就能屏蔽图中所有其他变量”，仅有父节点通常不够。**Markov 毯** (Markov blanket) 是一组这样的屏蔽变量。有向图为节点 i 给出一个标准的图上 Markov 毯：

$$\begin{aligned} \text{mb}(i) = & \text{pa}(i) \cup \text{ch}(i) \\ & \cup \bigcup_{j \in \text{ch}(i)} (\text{pa}(j) \setminus \{i\}). \end{aligned} \quad (17.3)$$

它由父节点、子节点及子节点的其他父节点组成。图 17.2 用 P, C, U 分别标出这三类节点。加入子节点，是因为它们会反映 X_i ；再加入子节点的其他父节点，是因为一旦给定子节点，原本在该子节点处相撞的路径可能打开。毯外节点 O 虽然可以间接影响毯内变量，但在给定整张毯以后不再提供关于 X_i 的额外信息。




图 17.2 有向图中节点 X_i 的 Markov 毯。黄色节点构成 $\text{mb}(i)$: P_1, P_2 是父节点， C_1, C_2 是子节点， U_1, U_2 是子节点的其他父节点；虚线节点 O 位于毯外。

定理 17.3 有向图中的 Markov 毯 设 $\mathcal{G} = (V, E)$ 为有限有向无环图， p 为节点随机变量 $\mathbf{X} = (X_i)_{i \in V}$ 的联合分布，且 $(\mathcal{G}, p)$ 构成有向图模型。则对每个节点 $i \in V$,

$$X_i \perp \mathbf{X}_{V \setminus (\{i\} \cup \text{mb}(i))} \mid \mathbf{X}_{\text{mb}(i)}.$$

设备模型中 $\text{mb}(H) = \{F, A, S\}$ ，所以虽无 H 与 S 之间的直接边， S 仍属于 H 的毯。特定分布中可能因参数冗余而存在更小的屏蔽集合，因此式 (17.3) 给出的是由图结构保证的毯，不保证对每一个具体分布都是最小集合。定理 17.3 的证明见第 19.2.3 节。

17.3 有向图的全局独立性

局部 Markov 性质只考察一个节点与非后代，全局 Markov 性质则同时考察任意两组节点之间的所有路径，因此覆盖的独立性查询更广。在有向图中，全局 Markov 性质蕴含局部 Markov 性质，局部性质又蕴含任一固定拓扑序下的有序 Markov 性质；本节建立全局判断规则并证明这两个蕴含，第 17.4.3 节再陈述四种表述的等价结论。

17.3.1 两个变量之间的四种基本关系

局部 Markov 性质围绕单个节点及其邻域建立屏蔽关系，而全局独立性需要检查连接两组节点的所有路径。进入一般定义以前，先看一条短路径上的四种基本关系。图 17.3 判断的是图对所有相容分布保证的独立性；“路径可以传递依赖”不等于任何参数下都实际存在依赖。下面的三节点结论以图中只有所画边为前提。在大图中，它们只说明这一条路径是否被阻断，别的路径仍须检查。




图 17.3 四种基本关系及给定中间节点前后的变化。链和分叉在同一小图中对照状态；碰撞关系拆成两列，空心 Z 表示未观测时阻断，红色填充 Z 表示给定后打开。活跃表示这条路径不再保证两端独立，并不保证任意参数下都实际相关。在更大的图中，碰撞节点的后代被给定也能打开该位置；直接连接则没有内部阻断点。

直接连接 $X \rightarrow Y$ 没有中间节点。因此，图本身不保证 $X \perp Y$ ；若所选

局部分布恰好满足 $p(y | x) = p(y)$ ，边存在而依赖仍会消失。第 17.3.3 节将给出具体参数，并借此区分模型类完备性与单个分布中的实际依赖。

链式关系 $X \rightarrow Z \rightarrow Y$ 表示 X 通过中间变量 Z 关联到 Y 。对顺序 X, Z, Y ，有序假设直接给出 $Y \perp X | Z$ 。等价的分解为 $p(x, z, y) = p(x)p(z | x)p(y | z)$ ，其一般证明见第 19.2.3 节；在 $p(z) > 0$ 时，它给出

$$p(x, y | z) = p(x | z)p(y | z).$$

不观测 Z 时，要把不同 z 对应的分布混合起来，这种混合通常保留 X 与 Y 之间的联系。反向画成 $X \leftarrow Z \leftarrow Y$ 时，条件独立结论相同；判断依赖不要求沿箭头从左走到右。

共同原因结构 $X \leftarrow Z \rightarrow Y$ 又称分叉。两端共享 Z ，所以不观测 Z 时可能相关；给定 Z 以后，图保证 $X \perp Y | Z$ 。例如，令 Z 等概率取 0 或 1，给定 Z 后 X, Y 独立，而且两者取 1 的概率在 $Z = 1$ 时均为 0.9，在 $Z = 0$ 时均为 0.1。于是 $p(X = 1) = p(Y = 1) = 0.5$ ，但 $p(X = 1, Y = 1) = (0.9^2 + 0.1^2)/2 = 0.41 \neq 0.25$ 。相关来自混合不同 Z 状态，而不是给定 Z 后仍有剩余关联。

共同结果结构 $X \rightarrow Z \leftarrow Y$ 又称碰撞结构，两条箭头在中间节点相遇。此时根节点独立，分解写成 $p(x)p(y)p(z | x, y)$ 。对 z 求和得到 $p(x, y) = p(x)p(y)$ ；固定 z 后，因子 $p(z | x, y)$ 却可能把两端耦合起来。例如，让 X, Y 为独立公平二值变量，并定义 $Z = 1$ 当且仅当至少一个输入为 1。已知 $Z = 1$ 时， $p(X = 1 | Z = 1) = 2/3$ ；再知道 $Y = 1$ ，这个概率降为 1/2。 Y 已经可以解释共同结果，因而降低了对 X 的需求。这种现象称为**解释消除** (explaining away)，即对一个共同结果的不同解释在观测后发生竞争。但竞争方向取决于参数，不能把“观测碰撞节点”直接翻译成“必然负相关”。

若碰撞节点的后代被观测，观测也可能间接提供关于碰撞节点的信息。图判据此将这一碰撞位置视为打开；能否形成实际依赖及其强弱，还取决于分布。例如，在 $X \rightarrow Z \leftarrow Y$ 后接 $Z \rightarrow D$ 并令 $D = Z$ ，观测 D 等价于观测 Z ；若 D 是有噪声的测量，影响强弱还取决于噪声水平。图只保证在碰撞节点及其所有后代均未被给定时，这条路径被阻断。这里的“共同原因”和“共同结果”用于辨认箭头形状，不是赋予概率图因果语义。

17.3.2 d-分离的定义

要判断两组变量之间的独立性，局部邻域还不够。即使一条路径已被观测阻断，另一条路径仍可能连接两端。此处的**路径** (path) 是忽略箭头方向后，由相邻且互不重复的节点组成的序列；只有明确说“有向路径”时，才要求沿箭头行进。




图 17.4 观测碰撞节点的后代也会打开路径。左图中 Z 及其后代都未给定， $X \rightarrow Z \leftarrow Y$ 被阻断；右图只把后代 D 填色为观测， Z 仍空心但用双圈标出已激活的碰撞位置，红色路径因 $Z \in \text{an}^+(S)$ 而打开。图结构只给出是否保证独立，不给出实际依赖强度。

在一条路径上，若某个内部节点 c 两侧的边都指向它，即出现 $\cdots \rightarrow c \leftarrow \cdots$ ，则称 c 是该路径的**碰撞节点** (collider)，否则称为非碰撞节点。碰撞是相对于路径而言的，同一个节点在一条路径上可能是碰撞节点，在另一条路径上则不是。对节点集 T ，记 $\text{an}(T) = \bigcup_{i \in T} \text{an}(i)$ ，并记 $\text{an}^+(T) = T \cup \text{an}(T)$ 。

定义 17.4 活跃路径与 d-分离 设 $A, B, S \subseteq V$ 两两不交，且 A, B 非空。一条连接 A 中节点与 B 中节点的路径在给定 S 时**活跃** (active)，当且仅当它的每个内部非碰撞节点都不属于 S ，且每个内部碰撞节点都属于 $\text{an}^+(S)$ 。后一个条件等价于碰撞节点自身或至少一个后代在 S 中。

若不存在这样的活跃路径，就称 A 与 B 被 S **d-分离** (d-separated)，记作 $A \perp_{\mathcal{G}} B \mid S$ ；否则称为 d-连接。

图 17.5 把两个条件同时画在设备路径上。给定碰撞节点 A 会打开路径，但给定非碰撞节点 H 会阻断路径；两种作用同时出现时，阻断仍然成立。

下标 $\mathcal{G}$ 提示这是图上的判断，而 $X_A \perp X_B \mid X_S$ 是分布中的条件独立。将二者连接起来的**全局 Markov 性质** (global Markov property) 要求：对每个两两不交的查询 (A, B, S) ，图中的 d-分离都蕴含分布中的相应条件独立。第 17.3.3 节会明确，这个蕴含对哪些分布成立。

引理 17.5 全局 Markov 性质蕴含局部 Markov 性质 设 $\mathcal{G} = (V, E)$ 为有限有向无环图， p 为节点随机变量 $\mathbf{X} = (X_i)_{i \in V}$ 的联合分布。若 p 满足 $\mathcal{G}$ 的全局 Markov 性质，则 p 也满足该图的局部 Markov 性质，并进一步满足任一固定拓扑序下的有序 Markov 性质。

(a) 给定 $\{A\}$: 路径活跃



(b) 给定 $\{H, A\}$: F 与 S 被 d -分离



图 17.5 活跃路径与 d -分离。上图只给定碰撞节点 A , 路径 $F \rightarrow H \rightarrow A \leftarrow S$ 活跃; 下图再给定非碰撞节点 H , 唯一的途径被阻断, 因而 $F \perp_g S \mid (H, A)$ 。红色节点表示给定变量, 黄色实线表示活跃路径, 灰色虚线表示被阻断的路径。

引理 17.5 的证明. 固定节点 i , 考虑 i 到任一非父非后代节点的路径。若路径从 i 的父节点一侧进入 i , 该父节点是路径内部的非碰撞节点, 给定 $\text{pa}(i)$ 便会阻断路径。若路径从 i 的出边开始, 则它不可能一直顺着箭头抵达非后代; 第一次不能继续沿箭头前进的转折处必为碰撞节点, 而且是 i 的后代。该碰撞节点及其后代都不可能属于 $\text{pa}(i)$, 否则会形成有向环, 所以给定父集不会打开它。每条路径都被阻断, 因而

$$i \perp_g \text{nd}(i) \setminus \text{pa}(i) \mid \text{pa}(i).$$

全局 Markov 性质据此给出局部 Markov 性质。任一合法拓扑序中的前驱都是非后代, 再从局部独立陈述中边缘化其余非后代, 就得到该顺序下的有序 Markov 性质。 ■

设备图中, F 与 S 之间只有 $F \rightarrow H \rightarrow A \leftarrow S$ 这一条路径。不给定任何节点时, A 是未打开的碰撞节点, 所以图保证 $F \perp S$ 。给定报警 A 后, H 仍是未观测的非碰撞节点, 而 A 已打开, 路径活跃; 再给定 H , 路径又在 H 处阻断, 因此图保证 $F \perp S \mid (H, A)$ 。如果在图上另加子节点 $A \rightarrow D$, 只观测 D 也会打开 A , 无需直接观测 A 。

这里的条件集合 S 表示“这些变量被给定”, 不表示把它们值设为 1。 d -分离保证一个完整的条件独立陈述, 即对允许的条件取值几乎处处成立。某些参数可能只在特定取值下出现额外独立性, 那是分布的上下文性质, 并不改变图上的 d -分离判断。

17.3.3 d-分离的可靠性与特定场景下的完备性

图没有记录条件概率表中的具体数值，所以需要区分两类问题：图中读出的独立性是否对每个相容分布都成立，以及图中没有分离的查询是否至少能在某个相容分布中表现为依赖。记 $\mathcal{M}(\mathcal{G})$ 为定义 17.1 给出的有向图模型所包含的分布类；第 17.4 节将陈述它与按 $\mathcal{G}$ 分解的分布类等价，证明见第 19.2.3 节。

定理 17.6 d-分离的可靠性 设 $\mathcal{G} = (V, E)$ 为有限有向无环图， $A, B, S \subseteq V$ 两两不交且 A, B 非空。对每个 $p \in \mathcal{M}(\mathcal{G})$,

$$A \perp_{\mathcal{G}} B \mid S \implies \mathbf{X}_A \perp_p \mathbf{X}_B \mid \mathbf{X}_S. \quad (17.4)$$

示例 17.7 未分离但独立的固定分布 考虑只有一条边 $X \rightarrow Y$ 的有向图，并令 $X, Y \in \{0, 1\}$ 。取 $p(X = 0) = p(X = 1) = 1/2$ ；对每个 $x \in \{0, 1\}$ ，取 $p(Y = 1 \mid X = x) = 1/3$ 和 $p(Y = 0 \mid X = x) = 2/3$ 。由于 X, Y 直接相邻，空集不能 d-分离它们。另一方面，边缘化 X 得到 $p(Y = 1) = 1/3$ 和 $p(Y = 0) = 2/3$ ，而对所有 $x, y \in \{0, 1\}$,

$$p(X = x, Y = y) = p(X = x)p(Y = y) = \begin{cases} 1/6, & y = 1, \\ 1/3, & y = 0. \end{cases}$$

因此，这个固定分布满足 $X \perp Y$ ，尽管图中 X 与 Y 未被 d-分离。

示例 17.7 只否定固定分布上的反向保证，即不能由图中未分离推出已经选定的相容分布必然不独立。它不否定严格正有限离散模型类和非退化线性高斯模型类中的存在性完备性。这种较弱的反向结论称为**模型类完备性**：图上的每项未分离查询，都能在相应模型类中找到一个实际不独立的相容分布。

第一个是**严格正有限离散模型**：每个变量只取有限多个状态，而且每个完整状态配置的联合概率都大于 0。固定每个节点的状态空间 $\mathcal{X}_i$ ，其中 $|\mathcal{X}_i| \geq 2$ ，记 $\mathcal{M}_{\text{disc}}^+(\mathcal{G})$ 为所有严格为正且按 $\mathcal{G}$ 分解的联合质量函数。第二个是**非退化线性高斯模型**：每个节点由父节点的线性函数加独立高斯噪声生成，正噪声方差保证联合高斯分布不集中在低维子空间上。记 $\mathcal{M}_{\text{LG}}(\mathcal{G})$ 为所有由方程

$$X_i = a_i + \sum_{j \in \text{pa}(i)} b_{i,j} X_j + \varepsilon_i$$

定义分布，其中边系数 $b_{i,j}$ 可取任意实数，噪声 ε_i 相互独立且满足 $\varepsilon_i \sim \mathcal{N}(0, \sigma_i^2)$ 、 $\sigma_i^2 > 0$ 。

定理 17.8 d-分离在特定模型类中的完备性 设 $\mathcal{G} = (V, E)$ 为有限有向无环图, $A, B, S \subseteq V$ 两两不交且 A, B 非空。若

$$A \not\perp_{\mathcal{G}} B \mid S,$$

则分别存在 $p_{\text{disc}} \in \mathcal{M}_{\text{disc}}^+(\mathcal{G})$ 与 $p_{\text{LG}} \in \mathcal{M}_{\text{LG}}(\mathcal{G})$, 使

$$X_A \not\perp_{p_{\text{disc}}} X_B \mid X_S, \quad X_A \not\perp_{p_{\text{LG}}} X_B \mid X_S. \quad (17.5)$$

可靠性与模型类完备性的量词并不对称。可靠性要求图中的每项分离对所有相容分布成立；模型类完备性只要求每项未分离查询至少存在一个不独立的相容分布，而且不同查询可以由不同分布见证。它不声称每个相容分布都在该查询上表现为依赖，因此与前面的固定分布反例并不矛盾。两个定理的证明统一放在第 19.2.3 节。

从一个固定分布中的条件独立反推图结构时，上述额外独立性会造成歧义。为排除这种歧义，需要另加**忠实性** (faithfulness)：固定分布中的每项条件独立都必须能由图中的 d-分离解释。

定义 17.9 忠实性 设 $p \in \mathcal{M}(\mathcal{G})$ 。若对每组两两不交且 A, B 非空的 $A, B, S \subseteq V$ 都有

$$X_A \perp_p X_B \mid X_S \implies A \perp_{\mathcal{G}} B \mid S,$$

就称 p 对 $\mathcal{G}$ 是**忠实的** (faithful)。结合可靠性，这等价于分布中的条件独立与图中的 d-分离对所有查询逐项相同。

忠实性不是有向图模型定义的一部分，也不由因子分解自动保证。固定确定性关系、强制参数共享或参数恰好抵消，都可能产生图中没有记录的额外独立性；结构学习若要把观察到的独立性解释为缺边，就必须另外说明为何可以采用忠实性假设。

17.3.4 d-分离的检测

d-分离的定义给出了逐条路径的判据，但大图中的路径数可能随图规模迅速增长。实际检测可以直接在有向图上传播有限种到达状态，也可以把当前查询转换为无向图上的连通性问题。

Bayes-ball 算法 在小图上，最可靠的起步方法是列出路径，逐个标记内部节点的角色，然后检查条件集合。设备图对 F, S 的查询可以汇总为表 17.1。这张表显示，增加观测既可能打开也可能关闭路径，因此不能采用“观测越多，独立性越多”的单调直觉。

给定节点	路径上的检查	图的结论
$\emptyset$	碰撞节点 A 未打开	F 与 S 分离
$\{H\}$	非碰撞节点 H 阻断	F 与 S 分离
$\{A\}$	A 打开, H 未阻断	F 与 S 连接
$\{H, A\}$	A 虽打开, H 仍阻断	F 与 S 分离

表 17.1 在 $F \rightarrow H \rightarrow A \leftarrow S$ 上逐项检查。表中的“连接”只是否定图保证的独立性，不声称任意参数下都不独立。

大图可能有指数多条路径，逐条枚举并不合适。**Bayes-ball 算法** (Bayes-ball algorithm) 不保存整条路径，而是记录“到达哪个节点、从哪一侧到达”这两个信息；相同状态只处理一次，重复路径因而合并。算法 17.1 给出只检测 d-分离的版本，不利用已知确定性关系额外剪枝，也不计算后验概率。状态 $(i, \uparrow)$ 表示从 i 的子节点一侧到达 i ，状态 $(i, \downarrow)$ 表示从父节点一侧到达 i 。

算法 17.1 Bayes-ball 的 d-分离检测

输入： 有向图 $\mathcal{G} = (V, E)$ ，两两不交的 $A, B, S \subseteq V$ ，且 A, B 非空

输出： “d-连接”或“d-分离”

```

1:  $R \leftarrow \text{an}^+(S)$ 
2: 队列  $Q \leftarrow \{(a, \uparrow) : a \in A\}$ 
3: 已处理状态集  $M \leftarrow \emptyset$ 
4: while  $Q$  非空 do
5:   从  $Q$  取出  $(i, \delta)$ 
6:   if  $(i, \delta) \in M$  then
7:     转到下一轮循环
8:   end if
9:    $M \leftarrow M \cup \{(i, \delta)\}$ 
10:  if  $i \in B$  then
11:    return d-连接
12:  end if
13:  if  $\delta = \uparrow$  且  $i \notin S$  then
14:    向  $Q$  加入  $\{(j, \uparrow) : j \in \text{pa}(i)\}$ 
15:    向  $Q$  加入  $\{(j, \downarrow) : j \in \text{ch}(i)\}$ 
16:  else if  $\delta = \downarrow$  then
17:    if  $i \notin S$  then
18:      向  $Q$  加入  $\{(j, \downarrow) : j \in \text{ch}(i)\}$ 
19:    end if
20:    if  $i \in R$  then
21:      向  $Q$  加入  $\{(j, \uparrow) : j \in \text{pa}(i)\}$ 
22:    end if
23:  end if
24: end while
25: return d-分离

```

从起点使用子侧状态, 使搜索能够同时沿入边和出边离开起点。从子侧到达 i 时, 只有 $i \notin S$ 才能穿过这个非碰撞位置; 此时搜索既可走向父节点, 也可走向子节点。从父侧到达 i 时, 继续走向子节点同样要求 $i \notin S$; 转向另一个父节点则在 i 处形成碰撞, 所以只要求 $i \in R$, 也就是 i 自身或其后代被观测。后两个条件彼此独立, 可能同时成立。伪码正好实现了活跃路径定义中的两类判断。

对查询 $F \perp S \mid A, R = \{F, H, A, S\}$ 。搜索从 F 到 H , 再从父侧到达 A ; A 虽然被观测, 但它属于 R , 搜索仍会转向父节点 S , 于是检测到活跃路径。若条件集合改为 $\{H, A\}$, 从父侧到达 H 后不能向子节点 A 传播, 搜索无法抵达 S 。这里必须记录到达方向, 仅用一个“访问过节点”标记会错误合并不同传播状态。

求 R 只需从 S 逆着箭头遍历祖先。主循环中每个节点至多处理两个到达状态, 每条边只被这些状态扫描常数次, 所以总时间和存储量均为 $O(|V| + |E|)^1$ 。

祖先道德图检测 除了直接在有向图上运行 Bayes-ball, 还可以使用**祖先道德图检测**: 先保留查询节点 $A \cup B \cup S$ 及其全部祖先, 把每个共同子节点的父节点两两相连并去掉箭头方向, 再删除条件节点 S 并检查 A 与 B 是否连通。转换必须依赖查询, 不能简单地把原图箭头全部擦掉; 第 19.2.2 节将在比较有向图与无向图时正式定义祖先图和道德图, 证明这一检测与 d -分离等价, 并讨论计算代价。这里的两种方法都只回答结构上的分离查询, 不能代替后验概率的数值计算。

¹ R. D. Shachter, *Bayes-Ball: The Rational Pastime (for Determining Irrelevance and Requisite Information in Belief Networks and Influence Diagrams)* In Proceedings of the Fourteenth Conference on Uncertainty in Artificial Intelligence, 1998, pp. 480–487

17.4 有向图中的因子分解

17.4.1 因子分解的定义

独立性告诉我们哪些信息可以省去, 而存储和计算联合分布需要一个具体表达式。**有向因子分解** (directed factorization) 把联合分布写成每个节点给定父节点的局部分布之积。局部项不是任意非负函数; 对每个父节点配置, 它必须是关于当前节点的归一化条件分布。

正式定义还需保证这些函数能够在联合空间上积分。下文要求基准测度为 σ 有限, 即状态空间可由可数个有限测度的集合覆盖; 有限或可数状态的计数测度、实数轴上的 Lebesgue 测度都满足这一点。每个 $\mathcal{A}_i$ 记录单坐标的可测事件, 乘积 σ 代数 $\bigotimes_i \mathcal{A}_i$ 则是由这些事件的笛卡尔积生成的联合可测事件集合。分解式中的“ μ 几乎处处”允许忽略乘积基准测度为零的集合, 因而不会改变积分所得的概率; 它与前文按条件变量边缘分布理解的“几乎处处”使用不同的测度。

定义 17.10 按有向图分解 给定有限有向图 $\mathcal{G} = (V, E)$, 其中 $V = \{1, \dots, d\}$ 。节点 i 取值于可测空间 $(\mathcal{X}_i, \mathcal{A}_i)$, 其上指定 σ 有限基准测度 μ_i ; 记 $(\mathcal{X}, \mathcal{A}) = (\prod_{i \in V} \mathcal{X}_i, \bigotimes_{i \in V} \mathcal{A}_i)$ 及 $\mu = \bigotimes_{i \in V} \mu_i$ 。设联合分布 p 对 μ 绝对连续, 并仍用 $p(\mathbf{x})$ 表示其可测密度。对每个节点 i , 选定局部条件质量函数或条件密度版本

$$q_i : \mathcal{X}_i \times \prod_{j \in \text{pa}(i)} \mathcal{X}_j \longrightarrow [0, \infty).$$

要求 q_i 关于相应乘积 σ 代数可测, 并对每个父节点配置 $\mathbf{x}_{\text{pa}(i)}$ 满足

$$\int_{\mathcal{X}_i} q_i(x_i | \mathbf{x}_{\text{pa}(i)}) d\mu_i(x_i) = 1.$$

若

$$p(\mathbf{x}) = \prod_{i=1}^d q_i(x_i | \mathbf{x}_{\text{pa}(i)}) \quad \mu \text{ 几乎处处}, \quad (17.6)$$

就称 p 按有向图 $\mathcal{G}$ 分解。父集为空时, 对应因子 $q_i(x_i)$ 是归一化的边缘质量函数或密度。有限离散变量情形取 $\mathcal{A}_i = 2^{\mathcal{X}_i}$ 和计数测度 μ_i , 上述积分即求和, p 与 q_i 均为概率质量函数, 式 (17.6) 对每个完整配置 $\mathbf{x}$ 逐点成立; 零质量父配置采用本章约定的归一化条件质量函数版本。连续变量情形中, q_i 是相对于已指定 μ_i 的条件密度版本, 式 (17.6) 相对于已定义的乘积测度 μ 几乎处处成立; 在零测集上改变密度版本不改变所表示的分布。

上述定义从已经给定的联合分布 p 出发, 判断它能否写成局部条件分布的乘积。实际建模时, 顺序往往相反: 先为每个节点指定一个局部条件函数, 此时还没有另外给出联合分布。下面的引理保证两件事: 每个局部条件函数按当前节点归一化时, 无环图上的乘积是合法联合分布; 对包含自身全部祖先的节点子集边缘化掉其余节点后, 所得边缘分布仍保持这些节点上的局部分解。引理同时写明这两项保证所需的状态空间、基准测度、可测性和局部归一化条件。

引理 17.11 局部归一化与祖先边缘化 设 $\mathcal{G} = (V, E)$ 为有限有向无环图, $V = \{1, \dots, d\}$ 。节点 i 取值于可测空间 $(\mathcal{X}_i, \mathcal{A}_i)$, 其上给定 σ 有限基准测度 μ_i ; 有限离散变量取计数测度。对每个节点 i , 设局部函数

$$q_i : \mathcal{X}_i \times \prod_{j \in \text{pa}(i)} \mathcal{X}_j \longrightarrow [0, \infty)$$

关于相应乘积 σ 代数可测, 并对每个父节点配置满足

$$\int_{x_i} q_i(x_i | \mathbf{x}_{\text{pa}(i)}) d\mu_i(x_i) = 1.$$

相对于乘积测度 $\mu = \bigotimes_{i \in V} \mu_i$ 定义

$$q(\mathbf{x}) = \prod_{i \in V} q_i(x_i | \mathbf{x}_{\text{pa}(i)}).$$

则 q 归一化, 因而是某个联合分布 p 的密度。更一般地, 若 $W \subseteq V$ 包含其中每个节点的全部祖先, 则 p 关于 $\mu_W = \bigotimes_{i \in W} \mu_i$ 的边缘密度满足

$$p(\mathbf{x}_W) = \prod_{i \in W} q_i(x_i | \mathbf{x}_{\text{pa}(i)}). \quad (17.7)$$

该等式对 μ_W 几乎处处成立; 有限离散情形中则对每个 $\mathbf{x}_W$ 逐点成立。

引理 17.11 的证明见第 19.2.3 节。如果允许有向环, 这个结论一般不成立。例如, 在二值环 $X \rightarrow Y \rightarrow X$ 上令 $q_X(x | y) = \mathbf{1}\{x = y\}$, $q_Y(y | x) = \mathbf{1}\{y = x\}$, 每个条件表都已归一化, 但乘积在 $(0, 0)$ 和 $(1, 1)$ 上都等于 1, 总和为 2。有向无环结构保证可以从末端消元; 存在有向环时, 这一消元论证不再适用, 局部归一化也不足以保证乘积归一化。

设备图的分解为

$$p(f, h, a, s) = p(f)p(s)p(h | f)p(a | h, s). \quad (17.8)$$

采用第 17.5.1 节将完整列出的教学参数, 一个具体配置的联合概率为

$$\begin{aligned} p(F = 1, H = 1, A = 1, S = 0) \\ &= p(F = 1)p(S = 0)p(H = 1 | F = 1)p(A = 1 | H = 1, S = 0) \quad (17.9) \\ &= 0.1 \times 0.95 \times 0.8 \times 0.9 = 0.0684. \end{aligned}$$

这个例子展示了分解的直接用途: 联合表中的一个表项不必单独存储, 可以从四个局部表项相乘得到。分解还可以简化边缘化。例如, 边缘化报警和传感器得到

$$\begin{aligned} p(f, h) &= p(f)p(h | f) \sum_s p(s) \sum_a p(a | h, s) \\ &= p(f)p(h | f). \end{aligned}$$

这个消元顺序利用了局部归一化。对同一组待边缘化变量, 按任意顺序求和都会得到相同结果, 但中间函数可能更大; 第 20 章将系统讨论这一计算差异。

17.4.2 从因子分解到条件独立性

从分解读取局部独立性时，必须先去掉后代。若直接在全联合分布中寻找含 x_i 的项，子节点因子也会包含 x_i ，不能只保留 i 自己的因子。

定理 17.12 分解蕴含局部与有序 Markov 性质 设 $\mathcal{G} = (V, E)$ 为有限有向无环图， p 为节点随机变量 $\mathbf{X} = (X_i)_{i \in V}$ 的联合分布。若 p 按 $\mathcal{G}$ 分解，则 p 满足该图的局部 Markov 性质，并满足该图任一固定拓扑序下的有序 Markov 性质。

定理 17.12 给出了分解到局部与有序 Markov 性质的方向。分解还蕴含全局 Markov 性质，这正是定理 17.6 的可靠性结论；这些证明统一放在第 19.2.3 节。

17.4.3 从条件独立性到因子分解

现在回到模型最初给出的固定拓扑序。概率链式法则对任意联合分布成立，而有序假设恰好告诉我们怎样缩短每个条件项。

定理 17.13 有序假设导出有向分解 设 $\mathcal{G} = (V, E)$ 为有限有向无环图， p 为节点随机变量 $\mathbf{X} = (X_i)_{i \in V}$ 的联合分布，并采用定义 17.10 中的有限离散质量函数或连续密度设定。若 p 满足 $\mathcal{G}$ 的某一个固定拓扑序下的有序 Markov 假设，则 p 按 $\mathcal{G}$ 分解。

定理 17.12 与定理 17.13 闭合有序性质、因子分解与局部性质；结合 d-分离可靠性以及全局性质蕴含局部性质，得到

$$\begin{aligned} \text{固定拓扑序的有序性质} &\iff \text{按有向图分解} \\ &\iff \text{局部 Markov 性质} \\ &\iff \text{全局 Markov 性质.} \end{aligned} \quad (17.10)$$

因而定义时只需选定一个拓扑序；由它得到分解，再由分解得到任一合法拓扑序的有序性质。这个等价关系不要求无向图分解定理中常见的严格正性条件；引理 17.5 已经证明全局性质到局部性质的方向，其余方向的证明见第 19.2.3 节。

式 (17.10) 讨论给定分布是否属于图模型类，不包含定理 17.8 的模型类完备性。后者需要为每个未分离查询构造至少一个不独立的相容分布，其证明也放在第 19.2.3 节。

17.5 局部参数化

因子分解确定了联合分布由哪些局部条件分布相乘得到，但还没有规定这些局部分布怎样表示、估计和采样。本节分别讨论离散变量与连续变量的常用参数化；它们改变局部因子的数值形式，不改变前面建立的图分解语义。

17.5.1 离散变量

结构和概率语义确定以后，还要选择怎样记录局部分布。若 X_i 有 r_i 个状态，父节点共有 $c_i = \prod_{j \in \text{pa}(i)} r_j$ 种配置，**条件概率表** (conditional probability table, CPT) 就为每个父配置存储一个长度 r_i 的概率向量。每行非负且和为 1，所以一个不受额外约束的表有 $c_i(r_i - 1)$ 个自由参数。整张网络的参数自由度为

$$m = \sum_{i=1}^d (r_i - 1) \prod_{j \in \text{pa}(i)} r_j. \quad (17.11)$$

若所有变量最多有 r 个状态、每个节点最多有 k 个父节点，存储完整条件表需要 $O(dr^{k+1})$ 空间。只限制节点数而不限制父集大小，不能保证紧凑表示。

设备模型的所有变量都为二值。两个根节点各需一个参数， H 有两个父配置， A 有四个父配置，因此共需 $1 + 1 + 2 + 4 = 8$ 个参数，而完全不受约束的四变量联合表需要 $2^4 - 1 = 15$ 个参数。取以下人工教学数值：

$$\begin{aligned} p(F = 1) &= 0.1, & p(S = 1) &= 0.05, \\ p(H = 1 \mid F = 1) &= 0.8, & p(H = 1 \mid F = 0) &= 0.1. \end{aligned}$$

报警表如表 17.2 所示，取 0 的概率由每行余数给出。

h	s	$p(A = 1 \mid h, s)$	$p(A = 0 \mid h, s)$
0	0	0.01	0.99
1	0	0.90	0.10
0	1	0.70	0.30
1	1	0.99	0.01

表 17.2 人工构造的报警条件概率表。每个固定 (h, s) 对应一个归一化二值分布，不表示真实设备的测量频率。

这些数值可以检验章首提出的观测现象。由局部表,

$$\begin{aligned} p(H = 1) &= 0.1 \times 0.8 + 0.9 \times 0.1 = 0.17, \\ p(A = 1 | H = 1) &= 0.95 \times 0.9 + 0.05 \times 0.99 = 0.9045, \\ p(A = 1 | H = 0) &= 0.95 \times 0.01 + 0.05 \times 0.7 = 0.0445, \\ p(A = 1) &= 0.17 \times 0.9045 + 0.83 \times 0.0445 = 0.1907. \end{aligned}$$

报警后过热的概率为 $0.153765/0.1907 \approx 0.8063$; 如果再获知传感器失灵, 则

$$p(H = 1 | A = 1, S = 1) = \frac{0.17 \times 0.99}{0.17 \times 0.99 + 0.83 \times 0.7} \approx 0.2246.$$

再对未观测的过热状态边缘化, 可比较故障的两个后验概率:

$$\begin{aligned} p(F = 1 | A = 1) &= \frac{0.07325}{0.1907} \approx 0.3841, \\ p(F = 1 | A = 1, S = 1) &= \frac{0.0932}{0.7493} \approx 0.1244. \end{aligned}$$

这些数值展示了同一组参数下的解释消除, 图结构则说明为什么这种依赖在给定报警后才被允许。

若有 n 个独立同分布且所有节点均已观测的样本 $\{\mathbf{x}_\ell\}_{\ell=1}^n$, 图固定, 各局部表参数之间没有共享约束, 则对数似然按节点和父配置分开。记 $N_{i,a,k}$ 为父配置等于 a 且 $X_i = k$ 的样本数, $N_{i,a} = \sum_k N_{i,a,k}$, $\theta_{i,a,k}$ 为对应的条件概率, 可得

$$\begin{aligned} \ell(\theta) &= \sum_i \sum_a \sum_k N_{i,a,k} \log \theta_{i,a,k}, \\ \hat{\theta}_{i,a,k} &= \frac{N_{i,a,k}}{N_{i,a}}. \end{aligned}$$

后一式对 $N_{i,a} > 0$ 成立, 可由每行概率和为 1 的约束下求极大值得到; $N_{i,a} = 0$ 时数据没有识别该行, 不能把 0/0 当成估计值。正伪计数 $\alpha_{i,a,k}$ 给出平滑估计 $(N_{i,a,k} + \alpha_{i,a,k}) / (N_{i,a} + \sum_k \alpha_{i,a,k})$, 它在狄利克雷先验下是后验均值。缺失变量、潜变量及共享参数会改变求解方式, 第 24 章进一步处理。

完整 CPT 的规模取决于父集与状态数, 也取决于局部结构。**参数共享** (parameter sharing) 让不同条件配置或不同节点复用同一组参数, 用更少自由度表达已知对称性, 但共享会约束原来的模型类。一个**确定性节点** (deterministic node) 则由父节点唯一决定, 离散局部分布写成 $p(x_i | \mathbf{x}_{\text{pa}(i)}) = \mathbf{1}\{x_i = g_i(\mathbf{x}_{\text{pa}(i)})\}$ 。它允许零概率配置, 不影响有向分解的可靠性, 却可能产生额外独立性。

若某个父节点只在特定条件下影响子节点, 就可以采用**上下文特定参数化** (context-specific parameterization), 即按部分父节点的取值选择较小的条件表或决策树。例如, 另构造一个报警模型, 使传感器失灵时 $p(A = 1 | H = h, S = 1) = 0.8$ 对所有 h 相同, 而 $S = 0$ 时保留对 H 的依

赖。这表示 $A \perp H \mid S = 1$ ，但不能推出 $A \perp H \mid S$ ，也不能删除全图中的 $H \rightarrow A$ 。利用相同行、确定性规则或树状局部结构可以压缩存储；是否降低推断代价，还取决于算法是否保持这些结构。

分解紧凑也不意味着任意推断都容易。评价一个完整配置只需查每个局部表并相乘；条件推断却通常需要对未观测变量求和，朴素枚举的规模随未观测变量数指数增长。图上的 d-分离检测是线性时间问题，而概率推断的复杂度由消元时产生的中间作用域决定，两者不可混淆。

17.5.2 连续变量

连续节点不能用有限 CPT 枚举所有父取值。一种可直接计算的选择是**线性高斯条件分布** (linear Gaussian conditional distribution)：父节点决定条件均值的线性部分，剩余不确定性用高斯噪声表示。对每个节点指定

$$p(x_i \mid \mathbf{x}_{\text{pa}(i)}) = \mathcal{N}\left(x_i; a_i + \sum_{j \in \text{pa}(i)} b_{i,j} x_j, \sigma_i^2\right), \quad (17.12)$$

$$\sigma_i^2 > 0.$$

其中 a_i 是截距， $b_{i,j}$ 是回归系数， σ_i^2 是条件噪声方差。等价地，可以用相互独立的 $\varepsilon_i \sim \mathcal{N}(0, \sigma_i^2)$ 写成线性方程。独立噪声是这个生成表示的一部分；若任意让不同节点的噪声相关，就不能继续声称同一组父集已经描述全部依赖。

把全部节点联立为 $\mathbf{X} = \mathbf{a} + \mathbf{B}\mathbf{X} + \boldsymbol{\varepsilon}$ ，记 $\mathbf{D} = \text{diag}(\sigma_1^2, \dots, \sigma_d^2)$ ，得到

$$\boldsymbol{\mu} = (\mathbf{I} - \mathbf{B})^{-1} \mathbf{a},$$

$$\boldsymbol{\Sigma} = (\mathbf{I} - \mathbf{B})^{-1} \mathbf{D} ((\mathbf{I} - \mathbf{B})^{-1})^\top.$$

严格下三角的 $\mathbf{B}$ 使 $\mathbf{I} - \mathbf{B}$ 总可逆，正噪声方差又保证 $\boldsymbol{\Sigma}$ 正定。因此，这组局部高斯分布构成非退化联合高斯分布，不需要另求配分函数。节点 i 只需 $|\text{pa}(i)| + 2$ 个参数，故完整参数数目为 $|E| + 2d$ 。

例如，令 $X_1 \sim \mathcal{N}(0, 1)$ ， $X_2 = 2X_1 + \varepsilon_2$ ， $X_3 = -X_2 + \varepsilon_3$ ，其中 $\varepsilon_2, \varepsilon_3$ 为独立标准高斯噪声且独立于 X_1 。链 $1 \rightarrow 2 \rightarrow 3$ 给出

$$\boldsymbol{\Sigma} = \begin{pmatrix} 1 & 2 & -2 \\ 2 & 5 & -5 \\ -2 & -5 & 6 \end{pmatrix}.$$

两端边缘协方差为 -2 ，但给定 X_2 后为 $-2 - 2(1/5)(-5) = 0$ ，符合链的 d-分离。这里从零条件协方差推出条件独立依赖联合高斯性，一般非高斯分布不能只靠协方差检验独立。

在所有节点均已观测、图固定和参数互不共享的条件下，若各节点的残差平方和为正，式 (17.12) 的最大似然估计可由逐节点对父变量作带截距的最小二乘回归得到，残差平方和除以 n 给出噪声方差估计。设计矩阵满列秩时回归系数唯一；秩不足时需要约束或正则化。若某个节点的残差完全为零且仍允许 σ_i^2 趋向零，似然会无界增大，非退化高斯模型内不存在有限最大值。线性均值与恒定条件方差也可能无法描述非线性、异方差或多峰数据，此时可以换局部分布，有向图的分解语义本身不变。

实际任务还可能混合离散状态与连续测量。**条件线性高斯模型** (conditional linear Gaussian model, CLG) 为每一种离散父配置设置一套线性高斯参数。记 D_i 与 C_i 分别为连续节点 i 的离散父集和连续父集。固定离散父配置 $\mathbf{X}_{D_i} = \mathbf{u}$ 时，局部分布与条件均值为

$$p(x_i | \mathbf{u}, \mathbf{x}_{C_i}) = \mathcal{N}(x_i; \mu_i(\mathbf{u}, \mathbf{x}_{C_i}), \sigma_{i,\mathbf{u}}^2),$$

$$\mu_i(\mathbf{u}, \mathbf{x}_{C_i}) = a_{i,\mathbf{u}} + \mathbf{b}_{i,\mathbf{u}}^\top \mathbf{x}_{C_i}.$$

标准 CLG 要求离散节点只有离散父节点，而连续节点可以有两类父节点；每个固定离散配置内的噪声方差为正，且不随连续父取值改变。这样，给定全部离散变量后，连续变量的联合分布是高斯分布。对离散变量求和后，则通常得到高斯混合，而不是单个高斯。若允许连续父节点指向采用逻辑回归条件分布的离散节点，仍能得到合法有向图模型，但已经超出这里的标准 CLG 类。它的推断不能直接套用“给定离散状态即高斯”的封闭计算规则；相关模型范围可参见 Koller 与 Friedman 教材的第 5 章²。

离散父配置多时，CLG 参数同样会膨胀。每个连续节点的自由参数数目为 $(\prod_{j \in D_i} r_j)(|C_i| + 2)$ ，所以高斯局部分布并未自动消除离散组合的指数规模。高斯条件化可以用线性代数计算，但对许多未知离散配置求和仍可能需要指数多个混合分量。

局部分布还有一个直接用途：生成完整样本。**祖先采样** (ancestral sampling) 按拓扑序取样，保证采样一个节点时，它的所有父节点值已经生成。

² D. Koller, N. Friedman, *Probabilistic Graphical Models: Principles and Techniques*, MIT Press, 2009

算法 17.2 有向图上的祖先采样

输入： 一个有向图、归一化局部条件分布及拓扑序 $1, \dots, d$
输出： 一个来自联合分布 p 的完整样本 $\mathbf{x}$

- 1: **for** $i = 1, \dots, d$ **do**
- 2: 读取已生成的父取值 $\mathbf{x}_{\text{pa}(i)}$
- 3: 从 $p(x_i | \mathbf{x}_{\text{pa}(i)})$ 采样 x_i
- 4: **end for**
- 5: **return** $\mathbf{x}$

由式 (17.6)，算法输出服从各局部条件分布共同定义的联合分布。拓扑

排序需 $O(d + |E|)$ 时间；一次完整采样的实际成本为拓扑遍历加上各节点局部采样成本。若表行选择和局部采样均可常数时间完成，就是线性遍历；线性高斯节点计算条件均值共需 $O(d + |E|)$ 时间。不能对任意复杂局部分布都默认常数采样成本。

例如，在设备模型的顺序 F, S, H, A 下，依次取四个独立均匀数 0.08、0.40、0.60 和 0.85。对二值节点，均匀数小于当前取 1 的概率时置 1，否则置 0。这次采样得到 $F = 1$ 、 $S = 0$ 、 $H = 1$ 、 $A = 1$ ，其联合概率就是式 (17.9) 计算的 0.0684。若目标是给定 $A = 1$ 后采样故障，就不能跳过报警采样而强行把 A 固定为 1，仍按先验生成其父节点；那样不会得到后验分布。可以对完整样本拒绝不符合证据者，或使用第 23 章的条件采样方法。祖先采样描述的是联合分布的一种概率生成顺序，不自动等于物理世界的因果生成机制。

17.6 本章小结

章首的报警问题包含两种不同的概率操作。给定链上的中间变量，可以屏蔽两端的联系；给定共同结果或其后代，却可能让原来独立的解释相互关联。 d -分离把这个差异推广到所有路径，判断依据是路径内部节点的角色以及条件集合，而不只是箭头能否从一端指向另一端。

有向图模型的定义只要求一个固定拓扑序下的有序 Markov 假设。链式法则把它转换为局部条件分布之积；祖先边缘化再从乘积分解导出局部独立性， d -分离的可靠性则导出全局独立性。反过来，全局性质包含局部性质，局部性质又包含固定顺序的有序性质，四种表述因此等价。这个闭合关系说明，图结构既能筛选相容分布，也能指导归一化、采样和计算；本章给出全局性质蕴含局部性质的图论证明，其余跨表示证明见第 19.2.3 节。

图没有记录参数数值。可靠性保证所有相容分布遵守图中的 d -分离，完备性只保证每个未分离查询都能在充分丰富的模型类中找到不独立的反例；特定参数的抵消、确定性或上下文限制仍可能产生额外独立性。离散条件表和连续条件分布把模型变为可用的数值对象，但局部表示紧凑、结构检测容易，都不保证条件推断容易。

本章的乘积由归一化局部分布和无环顺序共同保证合法。若相互作用更适合用没有方向的邻接关系描述，就不能继续依靠末端节点逐项归一化。第 18 章将从无向分离出发，讨论相应全局归一化、因子分解及其成立条件。

无向图模型

相邻像素的标签通常倾向于一致，但只凭这种相容关系，并不能指定哪个像素先生成、哪个像素后生成。第 17 章用有向边组织条件分布；当建模依据是变量之间对称的局部相互作用时，可以先不规定生成顺序，直接问：观察哪些变量以后，两组变量之间就不再提供额外信息？

这个问题有两个互相联系的方面。图上的路径说明信息可能沿哪些连接传递，条件独立性说明给定观测后分布怎样简化；要把这样的语义变成可计算的模型，还需要把联合分布写成局部函数的乘积。本章先建立无向图的三种 Markov 性质，再证明局部乘积与图分离之间的关系。两者并非无条件等价：零概率配置可能使条件独立性无法约束某些局部组合，而连续变量还要求密度可以归一化。这些条件决定了从图到分布、从分布到图的推理是否成立。

18.1 无向图模型的定义

考虑四个相邻区域的二值标签，用 $X_1, \dots, X_4$ 表示其状态。假设区域之间的直接相互作用沿一个环连接，即 1 与 2、2 与 3、3 与 4、4 与 1 相邻。这里的环不是时间上的循环，而是空间邻接关系。这个人工构造的小模型将贯穿本章：我们会用它检查分离关系、计算条件概率，并检验严格正性假设的作用。

无向图 (undirected graph) 用没有箭头的边记录对称连接。本章只考虑有限简单无向图 $\mathcal{G} = (V, E)$ ，其中 $V = \{1, \dots, d\}$ 是节点集合， E 是不同节点组成的无序对的集合，不含自环或重边。若 $\{i, j\} \in E$ ，就称 i 与 j 相邻；节点 i 的**邻居集合** (neighborhood) 记为

$$N(i) = \{j \in V : \{i, j\} \in E\}.$$

每个节点 i 对应一个标量随机变量 X_i ，其取值记为 x_i 。对节点集合 $A \subseteq V$ ， $\mathbf{X}_A$ 表示这些节点对应的随机向量， $\mathbf{x}_A$ 表示其取值。图的节点集合与随机变量的状态空间是不同对象，例如 $1 \in V$ 是节点编号，而 $x_1 = 0$ 是一次状

态取值。

从 i 到 j 的**路径** (path) 是一个从 i 开始、在 j 结束、相邻节点之间有边且节点不重复的序列。**连通分量** (connected component) 是不能再扩大的连通节点集合, 其中任意两个节点之间都存在路径。只保留节点集合 D 以及两端都在 D 内的原有边, 得到**诱导子图** (induced subgraph) $\mathcal{G}[D]$ 。后面检测条件独立性时, 会在删除观测节点后的诱导子图中检查连通性。

局部相互作用也可以同时涉及两个以上变量。**团** (clique) 是一个非空节点集合, 其中任意两个不同节点都相邻; 单节点集合也算团。**极大团** (maximal clique) 是不能再加入节点而仍保持为团的集合。“极大”表示不能继续扩张, 不表示它的节点数在全图中最多。图 18.1 左侧的环有四个二节点极大团, 没有三节点团; 右侧的两个三角形则分别形成极大团 $\{1, 2, 3\}$ 与 $\{3, 4, 5\}$ 。




图 18.1 两种无向连接。左图的极大团是四条边, 四节点形成环不等于形成团; 右图的两个三角形分别是极大团, 共享节点 3。线段没有方向, 节点编号对应随机变量下标。

无向图模型 (undirected graphical model) 也称**Markov 随机场** (Markov random field, MRF) 或**Markov 网络**。它把图上的阻断关系解释为分布中的条件独立性: 当一组观测节点阻断两侧之间的所有路径时, 给定这些观测, 两侧变量就相互独立。第 18.3 节将把这条全局语义写成正式定义。

图只规定分布必须满足哪些独立性, 没有规定局部函数的形式。对同一张图, 可以构造许多不同分布。无向边允许相邻变量存在直接概率相互作用, 但有边并不强迫它们在所有参数下都依赖; 缺边所表达的独立性才是必须满足的约束。模型也可能具有图中没有表现出来的额外独立性。因此, 不能把无向边自动读成因果作用, 更不能凭它指定干预后的分布。这里采用的图分离与 Markov 语义与无向图模型的标准表述一致¹。

¹S. L. Lauritzen, *Graphical Models*, Clarendon Press, 1996

18.2 无向图的局部独立性

直接核查所有节点集合之间的独立性很繁琐。可以先把视野缩小到两个节点, 或一个节点与其周围变量的关系。这得到两种容易从图上读出的条件独立性要求; 它们与全局要求何时等价, 需要单独证明。

18.2.1 成对 Markov 性质

若 i 与 j 之间没有边，图所承诺的并不是二者边缘独立。其他节点仍可能连接它们，未观测的中间变量也可能造成相关。成对约束把其余节点全部作为条件，排除这些间接联系。

定义 18.1 成对 Markov 性质 联合分布 p 相对于 $\mathcal{G}$ 满足**成对 Markov 性质** (pairwise Markov property)，是指对每一对不同且不相邻的节点 i, j ，都有

$$X_i \perp X_j \mid \mathbf{X}_{V \setminus \{i, j\}}. \quad (18.1)$$

四节点环缺少 $\{1, 3\}$ 和 $\{2, 4\}$ 两条边，所以成对性质恰好要求

$$X_1 \perp X_3 \mid (X_2, X_4), \quad X_2 \perp X_4 \mid (X_1, X_3).$$

第一个条件必须同时给定 X_2 与 X_4 。只给定 X_2 仍保留路径 $1-4-3$ ，不能由这张图推出 $X_1 \perp X_3 \mid X_2$ 。

在离散情形，条件独立性只要求对满足 $p(\mathbf{x}_{V \setminus \{i, j\}}) > 0$ 的条件配置，二元条件概率能够分成两个条件边缘概率的乘积。概率为零的条件事件不需要、通常也不能用概率比定义条件分布。连续情形则使用条件密度或正则条件分布，等式按条件变量分布几乎处处成立；不能用“单点事件有正概率”作为连续变量的前提。

成对性质逐一检查缺边，便于列出约束，却没有直接说明两个较大变量集合之间是否独立。尤其要小心：条件越多不意味着独立性越强，从多个给定大量变量的成对结论中删去部分条件，并不是条件独立性的一般运算规则。

18.2.2 局部 Markov 性质

对单个节点 i 而言，任何通向远处节点的路径都必须先经过它的某个邻居。因此，如果图分离确实对应条件独立性，给定全部邻居就应足以屏蔽图中其余变量。

定义 18.2 局部 Markov 性质 联合分布 p 相对于 $\mathcal{G}$ 满足**局部 Markov 性质** (local Markov property)，是指对每个 $i \in V$ ，都有

$$X_i \perp \mathbf{X}_{V \setminus (\{i\} \cup N(i))} \mid \mathbf{X}_{N(i)}. \quad (18.2)$$

能够在给定后使 X_i 与其他变量独立的节点集合称为它的**Markov 毯** (Markov blanket)，即对预测 X_i 而言已经包含其他变量所能提供的信息的集合。只要分布满足相对于图的局部 Markov 性质，邻居集合 $N(i)$ 就

是图结构保证的一个 Markov 毯。图 18.2 把这项保证画成三层：从 i 通向任一远端非邻居的路径，离开 i 后的第一个节点必定属于 $N(i)$ 。




图 18.2 无向图中节点 i 的结构性 Markov 毯。双边框大圆表示中心节点 i ，单边框小圆表示邻居 n_1, n_2, n_3 ，方形表示远端非邻居。图中所有线段都是现存的无向边，统一使用实线；由于 i 不与方形节点直接相连，从 i 通向远端节点的路径都先经过 $N(i)$ 。

在相应条件分布有定义时，这项屏蔽关系还可以写成

$$p(x_i | \mathbf{x}_{V \setminus \{i\}}) = p(x_i | \mathbf{x}_{N(i)}). \quad (18.3)$$

这是邻居集合的充分性，不是固定分布 p 下的最小性保证。若某条边的参数实际上不产生依赖，删去对应邻居后仍可能构成 Markov 毯；图中的环也不妨碍这项结构保证，因为每条离开 i 的路径仍要先经过邻居。




图 18.3 两种不满足严格正性的反例图。左侧空图用于说明成对 Markov 性质不蕴含局部 Markov 性质；右侧两条不相连的边用于说明局部与成对 Markov 性质都不蕴含全局 Markov 性质。两例都令各节点变量等于同一个公平二值变量 U 。

示例 18.3 成对性质不蕴含局部性质 考虑图 18.3 左侧的三节点空图。令 U 服从公平的 Bernoulli 分布，并令

$$X_1 = X_2 = X_3 = U.$$

空图中的三对节点都不相邻，所以成对性质需要逐项检查

$$X_1 \perp X_2 \mid X_3, \quad X_1 \perp X_3 \mid X_2, \quad X_2 \perp X_3 \mid X_1.$$

对第一项，任取 $u, a, b \in \{0, 1\}$ ，在正概率条件事件 $X_3 = u$ 下，

$$\begin{aligned} p(X_1 = a, X_2 = b \mid X_3 = u) &= \mathbf{1}\{a = u\}\mathbf{1}\{b = u\} \\ &= p(X_1 = a \mid X_3 = u)p(X_2 = b \mid X_3 = u). \end{aligned}$$

将 $(X_1, X_2; X_3)$ 依次换成 $(X_1, X_3; X_2)$ 和 $(X_2, X_3; X_1)$ ，同一等式分别验证其余两项。因此该分布满足全部成对 Markov 约束。

空图中 $N(1) = \emptyset$ ，节点 1 的局部性质却要求 $X_1 \perp (X_2, X_3)$ 。实际有

$$p(X_1 = 0, (X_2, X_3) = (0, 0)) = \frac{1}{2} \neq p(X_1 = 0)p((X_2, X_3) = (0, 0)) = \frac{1}{4}.$$

仅这一项失败就足以说明局部性质不成立。该反例的联合分布只在 $(0, 0, 0)$ 与 $(1, 1, 1)$ 上为正；条件变量消除了成对约束中的随机性，却没有消除不加条件时三个变量共享的依赖。

定理 18.4 局部 Markov 性质蕴含成对 Markov 性质 设 $\mathcal{G} = (V, E)$ 为有限简单无向图， p 为节点随机变量 $\mathbf{X} = (X_i)_{i \in V}$ 的任意联合分布。若 p 相对于 $\mathcal{G}$ 满足局部 Markov 性质，则它满足成对 Markov 性质；该结论不要求 p 严格为正。

证明. 固定任意不相邻节点 i, j ，记 $R = V \setminus (\{i\} \cup N(i))$ ，则 $j \in R$ 。局部性质给出

$$X_i \perp \mathbf{X}_R \mid \mathbf{X}_{N(i)}.$$

这里需要把部分非邻居移入条件集合，所用规则是**弱并** (weak union)：

$$X \perp (Y, Z) \mid W \implies X \perp Y \mid (W, Z).$$

前提给出 $p(x \mid y, z, w) = p(x \mid w)$ ；按 $p(y \mid z, w)$ 对 y 边缘化，又得 $p(x \mid z, w) = p(x \mid w)$ 。两式合起来说明，给定 (Z, W) 后再观察 Y 不会改变 X 的条件分布。等式只在相应条件分布有定义的配置上使用，连续情形按条件变量分布几乎处处理解，因此不需要联合分布严格为正。

将 R 写成 $\{j\} \cup (R \setminus \{j\})$ ，应用弱并规则，得到

$$X_i \perp X_j \mid (\mathbf{X}_{N(i)}, \mathbf{X}_{R \setminus \{j\}}).$$

右侧条件变量的节点集合正是 $V \setminus \{i, j\}$, 因此这就是节点 i, j 对应的成对 Markov 约束。由于 i, j 是任意不相邻节点, 所有成对约束都成立。 ■

局部性质同时约束所有非邻居, 但只给定邻居; 成对性质只约束一个非邻居, 却把其余节点全部作为条件。四节点环中每个节点只有一个非邻居, 所以两种表述在这个特例中重合。在更大的图上, 区别就很实质。例如链 $1-2-3-4$ 上, 节点 1 的局部性质要求 $X_1 \perp (X_3, X_4) \mid X_2$, 不是仅分别要求 $X_1 \perp X_3 \mid (X_2, X_4)$ 和 $X_1 \perp X_4 \mid (X_2, X_3)$ 。

18.3 无向图的全局独立性

局部视角告诉我们怎样屏蔽一个节点, 但推断任务往往涉及两组变量。比如在图 18.1 右侧, 观察共享节点 3 以后, 左侧区域 $\{1, 2\}$ 与右侧区域 $\{4, 5\}$ 之间还需要联合推断吗? 回答这类问题, 需要直接检查集合之间的路径。

18.3.1 全局 Markov 性质

全局 Markov 性质 (global Markov property) 把所有路径阻断关系同时转成概率约束。与成对和局部性质相比, 它允许两端都是节点集合, 条件集合也只需阻断两端之间的路径。

定义 18.5 全局 Markov 性质 设 p 为 $\mathbf{X} = (X_1, \dots, X_d)^\top$ 的联合分布。若对任意两两不交的节点集合 $A, B, S \subseteq V$, 只要从任意 $a \in A$ 到任意 $b \in B$ 的每条路径都经过 S 中的节点, 就有

$$\mathbf{X}_A \perp \mathbf{X}_B \mid \mathbf{X}_S, \quad (18.4)$$

则称 p 相对于 $\mathcal{G}$ 满足全局 Markov 性质, $(\mathcal{G}, p)$ 构成一个无向图模型。

定义要求的是“路径被阻断就有独立性”, 不要求反向成立。如果图中仍有路径, 只能说图没有保证相应独立性, 不能立即断言两端变量必然相关。在两个三角形共享节点 3 的图中, 每条从 $\{1, 2\}$ 到 $\{4, 5\}$ 的路径都经过 3, 所以全局性质给出

$$(X_1, X_2) \perp (X_4, X_5) \mid X_3.$$

给定 X_3 后, 联合条件分布分成左右两个二元分布; 它没有要求 X_1 与 X_2 独立, 也没有要求 X_4 与 X_5 独立。

全局性质允许 $A \cup B \cup S \neq V$ 。若只查询 X_1 与 X_5 , X_2, X_4 可以既不被查询也不被观测, 结论 $X_1 \perp X_5 \mid X_3$ 仍由同一路径阻断条件保证。证明某个分布族满足全局性质时, 必须把这些未查询变量消去, 不能只证明三个集合覆盖全部节点的特殊情形。

定理 18.6 全局 Markov 性质蕴含局部与成对 Markov 性质 设 $\mathcal{G} = (V, E)$ 为有限简单无向图, p 为节点随机变量 $\mathbf{X} = (X_i)_{i \in V}$ 的任意联合分布。若 p 相对于 $\mathcal{G}$ 满足全局 Markov 性质, 则它同时满足局部与成对 Markov 性质。换言之, 不附加严格正性时总有

$$\text{全局 Markov} \implies \text{局部 Markov} \implies \text{成对 Markov}. \quad (18.5)$$

证明. 固定 $i \in V$. 从 i 到任一非邻居的路径离开 i 时, 必先进入 $N(i)$ 中的某个节点。因此 $N(i)$ 阻断 $\{i\}$ 与 $V \setminus (\{i\} \cup N(i))$ 之间的每条路径。把这三个集合代入全局 Markov 性质, 得到

$$X_i \perp \mathbf{X}_{V \setminus (\{i\} \cup N(i))} \mid \mathbf{X}_{N(i)},$$

即节点 i 的局部 Markov 性质。该结论对每个 i 都成立, 所以 p 满足局部性质; 再应用定理 18.4, 得到成对性质。 ■

式 (18.5) 的反向箭头都可能在退化分布上失效。图 18.3 右侧给出一个同时检验局部、成对和全局性质的例子。

示例 18.7 局部、成对均不蕴含全局 考虑边集 $E = \{\{1, 2\}, \{3, 4\}\}$, 并令

$$X_1 = X_2 = X_3 = X_4 = U, \quad U \sim \text{Bernoulli}(\frac{1}{2}).$$

局部性质需要逐项验证

$$\begin{aligned} X_1 \perp (X_3, X_4) \mid X_2, \quad X_2 \perp (X_3, X_4) \mid X_1, \\ X_3 \perp (X_1, X_2) \mid X_4, \quad X_4 \perp (X_1, X_2) \mid X_3. \end{aligned}$$

以第一项为例, 对任意 $u, a, r_3, r_4 \in \{0, 1\}$,

$$\begin{aligned} & p(X_1 = a, X_3 = r_3, X_4 = r_4 \mid X_2 = u) \\ &= \mathbf{1}\{a = u\} \mathbf{1}\{r_3 = u, r_4 = u\} \\ &= p(X_1 = a \mid X_2 = u) p(X_3 = r_3, X_4 = r_4 \mid X_2 = u). \end{aligned}$$

第二、第三和第四项分别把条件变量换成 X_1, X_4, X_3 , 并把单节点端点换成 X_2, X_3, X_4 ; 在每个正概率条件事件下, 完全相同的指标函数分解成立。因此四项局部约束全部成立。

成对性质要检查的四条缺边是 $\{1, 3\}$ 、 $\{1, 4\}$ 、 $\{2, 3\}$ 与 $\{2, 4\}$, 相应约束为

$$\begin{aligned} X_1 \perp X_3 \mid (X_2, X_4), \quad X_1 \perp X_4 \mid (X_2, X_3), \\ X_2 \perp X_3 \mid (X_1, X_4), \quad X_2 \perp X_4 \mid (X_1, X_3). \end{aligned}$$

对任一缺边 $\{i, j\}$, 条件变量只有取共同值 (u, u) 时概率为正, 并且

$$p(X_i = a, X_j = b \mid X_{V \setminus \{i, j\}} = (u, u)) = \mathbf{1}\{a = u\} \mathbf{1}\{b = u\}.$$

右侧正好是两个条件边缘概率的乘积, 所以列出的四项成对约束也全部成立。

但空集阻断两条不相连边之间的所有路径, 全局性质因而要求 $(X_1, X_2) \perp (X_3, X_4)$ 。这个要求失败, 因为

$$p(X_1 = 0, X_3 = 0) = \frac{1}{2} \neq p(X_1 = 0)p(X_3 = 0) = \frac{1}{4}.$$

若两个向量独立, 其分量 X_1 与 X_3 也应独立, 故上式足以否定全局性质。

要沿反方向从许多成对约束恢复集合之间的独立性, 需要把分别位于条件集合中的变量合并到同一个端点。**交集性质** (intersection property) 保证这种合并: 两条独立性若分别把对方的端点放在条件中, 就可以同时移出这两部分条件并合并端点。它不对任意分布成立, 下面先在严格正有限离散情形中证明。

引理 18.8 严格正分布的交集性质 设 I 为有限索引集, 每个 $i \in I$ 对应取值于有限非空状态空间 $\mathcal{X}_i$ 的随机变量 X_i 。令 p 为 $\mathbf{X} = (X_i)_{i \in I}$ 在乘积状态空间 $\mathcal{X} = \prod_{i \in I} \mathcal{X}_i$ 上的联合质量函数, 且 $p(\mathbf{x}) > 0$ 对所有 $\mathbf{x} \in \mathcal{X}$ 成立。对两两不交的索引集 $A, B, C, D \subseteq I$, 若

$$\mathbf{X}_A \perp \mathbf{X}_B \mid (\mathbf{X}_C, \mathbf{X}_D), \quad \mathbf{X}_A \perp \mathbf{X}_D \mid (\mathbf{X}_C, \mathbf{X}_B),$$

则

$$\mathbf{X}_A \perp (\mathbf{X}_B, \mathbf{X}_D) \mid \mathbf{X}_C.$$

证明. 严格正性保证以下每个条件概率都有定义。对任意取值 $\mathbf{a}, \mathbf{b}, \mathbf{c}, \mathbf{d}$, 两个前提分别给出

$$p(\mathbf{a} \mid \mathbf{b}, \mathbf{c}, \mathbf{d}) = p(\mathbf{a} \mid \mathbf{c}, \mathbf{d}), \quad p(\mathbf{a} \mid \mathbf{b}, \mathbf{c}, \mathbf{d}) = p(\mathbf{a} \mid \mathbf{b}, \mathbf{c}).$$

因此 $p(\mathbf{a} \mid \mathbf{c}, \mathbf{d}) = p(\mathbf{a} \mid \mathbf{b}, \mathbf{c})$ 对每个 $\mathbf{b}, \mathbf{d}$ 成立。固定任意基准值 $\mathbf{b}^\circ$, 右侧等于 $q(\mathbf{a}, \mathbf{c}) = p(\mathbf{a} \mid \mathbf{b}^\circ, \mathbf{c})$, 不再依赖 $\mathbf{b}$ 或 $\mathbf{d}$ 。对 $(\mathbf{b}, \mathbf{d})$ 关于 $p(\mathbf{b}, \mathbf{d} \mid \mathbf{c})$ 求和可得 $q(\mathbf{a}, \mathbf{c}) = p(\mathbf{a} \mid \mathbf{c})$, 故 $p(\mathbf{a} \mid \mathbf{b}, \mathbf{c}, \mathbf{d}) = p(\mathbf{a} \mid \mathbf{c})$, 这正是所需的条件独立性。 ■

为了看清交集性质怎样合并集合, 先记录一个可重复使用的步骤。设

$A, C, Y \subseteq V$ 两两不交, 且非空集合 $Y = \{y_1, \dots, y_m\}$ 。若对每个 y_k 都有 $\mathbf{X}_A \perp \mathbf{X}_{y_k} \mid (\mathbf{X}_C, \mathbf{X}_{Y \setminus \{y_k\}})$, 令 $D_0 = \emptyset$ 、 $D_k = \{y_1, \dots, y_k\}$ 、 $T_k = Y \setminus D_k$ 。当 $k = 1$ 时, 原前提直接给出 $\mathbf{X}_A \perp \mathbf{X}_{D_1} \mid (\mathbf{X}_C, \mathbf{X}_{T_1})$ 。对 $k \geq 2$, 若已经得到 $\mathbf{X}_A \perp \mathbf{X}_{D_{k-1}} \mid (\mathbf{X}_C, \mathbf{X}_{y_k}, \mathbf{X}_{T_k})$, 而 y_k 对应的原前提写成 $\mathbf{X}_A \perp \mathbf{X}_{y_k} \mid (\mathbf{X}_C, \mathbf{X}_{D_{k-1}}, \mathbf{X}_{T_k})$, 应用交集性质便得到 $\mathbf{X}_A \perp \mathbf{X}_{D_k} \mid (\mathbf{X}_C, \mathbf{X}_{T_k})$ 。逐个合并到 $T_m = \emptyset$, 最终得到 $\mathbf{X}_A \perp \mathbf{X}_Y \mid \mathbf{X}_C$ 。

定理 18.9 严格正条件下三种 Markov 性质等价 设 $\mathcal{G} = (V, E)$ 为有限简单无向图, 每个节点 $i \in V$ 对应取值于有限非空状态空间 $\mathcal{X}_i$ 的随机变量 X_i 。令 p 为 $\mathbf{X} = (X_i)_{i \in V}$ 在乘积状态空间 $\mathcal{X} = \prod_{i \in V} \mathcal{X}_i$ 上的联合质量函数, 并且 $p(\mathbf{x}) > 0$ 对所有 $\mathbf{x} \in \mathcal{X}$ 成立。则 p 相对于 $\mathcal{G}$ 的成对、局部与全局 Markov 性质等价。

证明. 定理 18.6 已经证明“全局 $\Rightarrow$ 局部 $\Rightarrow$ 成对”, 只需证明成对性质蕴含全局性质。取满足全局性质定义中路径阻断条件的非空集合 A, B 与条件集合 S 。令 U 为 $\mathcal{G}[V \setminus S]$ 中所有与 A 相交的连通分量之并, 并令 $W = V \setminus (S \cup U)$ 。路径阻断条件保证 $A \subseteq U$ 、 $B \subseteq W$, 而 U 与 W 之间没有边。

固定 $u \in U$ 。对每个 $w \in W$, 成对性质给出

$$X_u \perp X_w \mid (\mathbf{X}_S, \mathbf{X}_{U \setminus \{u\}}, \mathbf{X}_{W \setminus \{w\}}).$$

在上一段的集合合并步骤中取 $Y = W$ 、条件基集 $C = S \cup (U \setminus \{u\})$, 逐个合并 W 中的节点, 得到

$$X_u \perp \mathbf{X}_W \mid (\mathbf{X}_S, \mathbf{X}_{U \setminus \{u\}}).$$

对每个 $u \in U$ 都成立。利用条件独立性的对称性把它写成 $\mathbf{X}_W \perp X_u \mid (\mathbf{X}_S, \mathbf{X}_{U \setminus \{u\}})$, 再取 $Y = U$ 、条件基集 $C = S$ 进行第二轮合并, 得到 $\mathbf{X}_W \perp \mathbf{X}_U \mid \mathbf{X}_S$ 。再次使用对称性与分解性质, 便有 $\mathbf{X}_A \perp \mathbf{X}_B \mid \mathbf{X}_S$, 所以任意满足路径阻断条件的三个集合都对应所需的条件独立性。■

两个反例解释了严格正性的作用。三节点空图只在两个完整配置上取正概率, 两条不相连边的图也只在 $(0, 0, 0, 0)$ 与 $(1, 1, 1, 1)$ 上取正概率; 交集引理所需的其他配置全部缺失。严格正性不是定义三种 Markov 性质的前提, 而是恢复逆向蕴含的一项充分条件。

18.3.2 图分离的定义

图分离 (graph separation) 描述的是纯粹的图结构事实, 还没有涉及概率。对两两不交的 $A, B, S \subseteq V$, 若从任意 $a \in A$ 到任意 $b \in B$ 的每条路径都包含 S 中的节点, 就称 S 在 $\mathcal{G}$ 中分离 A 与 B 。这里 S 称为分离集; 它不必是

最小分离集，也不必包含图上所有其余节点。若 A 与 B 原本就位于不同连通分量，空集也能分离它们。

无向图没有箭头，因而不需要区分第17章中的碰撞节点和非碰撞节点。条件集合中的节点直接阻断经过它的路径，不存在“观测碰撞节点反而打开路径”的图判据。但这并不意味着可以忽略多条路径：只阻断其中一条，仍不足以形成分离。

图18.4展示了四节点环的两种条件集合。 $S = \{2\}$ 阻断 $1-2-3$ ，却保留 $1-4-3$ ； $S = \{2, 4\}$ 才分离 $\{1\}$ 与 $\{3\}$ 。图分离对条件集合具有单调性：在不加入 A 、 B 节点的前提下，继续删除节点不会创造新路径。这个单调性属于图判据，不能替代一般概率分布中的条件独立性推理。




图18.4 删除条件节点以检测分离。方形节点属于 S ，虚线边随节点一同删除，实线边保留。左侧删除2后仍有路径 $1-4-3$ ；右侧同时删除2,4后，1与3处于不同连通分量。

18.3.3 图分离的检测

检测分离不必枚举路径。构造 $\mathcal{G}[V \setminus S]$ ，从 A 中的所有节点同时进行广度优先搜索；若能够访问 B 中的任意节点， S 就不是分离集，否则就是。搜索过程中只沿未删除的节点与边扩张，因而访问到的恰好是与 A 有剩余路径连接的节点。这也证明了该检测方法的正确性。采用邻接表与标记数组时，一次查询的最坏时间为 $O(d + |E|)$ ，额外空间为 $O(d)$ 。图上的查询可以很快完成，并不代表相应的概率数值也容易计算。

18.3.4 图分离的可靠性与模型类完备性

图分离给出的是结构判据。要说明这个判据恰好能表达什么，需要区分两个方向：**可靠性** (soundness) 要求图判定为分离时，模型类中的每个分布都满足相应条件独立性；**完备性** (completeness) 要求图判定为不分离时，模型类中至少存在一个分布使相应条件独立性失败。完备性是模型类层面的存在性结论，不保证任意固定参数都产生依赖。

下面先用局部权重构造一个具体分布。给一组局部变量的每种状态组合指定非负权重，这个函数称为**势函数** (potential function)，简称势；它本身无需归一化。对每个完整配置，将相应的局部权重相乘，再除以所有

完整配置的权重总和，才得到概率。有限离散情形下，这个总和称为**配分函数** (partition function)，记为 Z ，并要求 $Z > 0$ 。

示例 18.10 不分离不强迫固定分布相关 考虑节点集 $V = \{1, 2\}$ 、边集 $E = \{\{1, 2\}\}$ 的无向图，并令 $X_1, X_2 \in \{-1, +1\}$ 。在唯一的二节点团上取常数边势

$$\psi_{\{1,2\}}(x_1, x_2) = 1.$$

两个二值变量共有四个完整配置，各自权重都是 1，所以 $Z = 1 + 1 + 1 + 1 = 4$ 。归一化后，四个配置都满足 $p(x_1, x_2) = 1/4$ ，分布处处严格为正。两个边缘分布都均匀，因而对任意 x_1, x_2 都有

$$p(x_1, x_2) = \frac{1}{4} = \frac{1}{2} \cdot \frac{1}{2} = p(x_1)p(x_2),$$

即 $X_1 \perp X_2$ 。空集不能分离由单边直接连接的端点，但这个固定分布仍然独立。因此，该例否定的是“不分离会使每个固定分布都相关”的反向保证，并不否定模型类完备性；后者只要求在同一模型类中至少存在一个分布使这项未分离查询不独立。

定理 18.11 团因子分解分布上的分离可靠性 设 $\mathcal{G} = (V, E)$ 为有限简单无向图，节点 $i \in V$ 取值于可测空间 $(\mathcal{X}_i, \mathcal{A}_i)$ ，其上给定 σ 有限基准测度 μ_i ；记 $\mathcal{X} = \prod_{i \in V} \mathcal{X}_i$ 及 $\mu = \bigotimes_{i \in V} \mu_i$ ，有限离散情形取计数测度。令 $\mathcal{C}$ 为 $\mathcal{G}$ 的有限团族，且对每个 $C \in \mathcal{C}$ ， $\psi_C : \mathcal{X}_C \rightarrow [0, \infty)$ 是可测函数，其中 $\mathcal{X}_C = \prod_{i \in C} \mathcal{X}_i$ 。若 p 相对于 μ 的密度满足

$$p(\mathbf{x}) = \frac{1}{Z} \prod_{C \in \mathcal{C}} \psi_C(\mathbf{x}_C) \quad \mu \text{ 几乎处处},$$

$$Z = \int_{\mathcal{X}} \prod_{C \in \mathcal{C}} \psi_C(\mathbf{x}_C) d\mu(\mathbf{x}), \quad 0 < Z < \infty,$$

则对任意两两不交且 A, B 非空的 $A, B, S \subseteq V$ ，若 S 在 $\mathcal{G}$ 中分离 A 与 B ，就有

$$\mathbf{X}_A \perp \mathbf{X}_B \mid \mathbf{X}_S.$$

势函数可以取零，不要求 p 严格为正。

这个结论的证明需要把分离集两侧的团势分别归一化，并消去不属于 $A \cup B \cup S$ 的变量。第 18.4.2 节将在给出因子分解的精确定义后证明定理 18.11。

定理 18.12 严格正二值成对势模型类中的分离完备性 设 $\mathcal{G} = (V, E)$ 为有限简单无向图, 每个节点 $i \in V$ 对应二值随机变量 $X_i \in \{-1, +1\}$, 且 $A, B, S \subseteq V$ 两两不交、 A, B 非空。若 S 在 $\mathcal{G}$ 中不分离 A 与 B , 则存在一个严格正且按 $\mathcal{G}$ 分解的成对势模型

$$p(\mathbf{x}) = \frac{1}{Z} \prod_{\{i,j\} \in E} \psi_{\{i,j\}}(x_i, x_j), \quad \psi_{\{i,j\}}(x_i, x_j) > 0,$$

使 $X_A \perp\!\!\!\perp X_B \mid X_S$ 。

证明. 因为 S 不分离 A 与 B , 存在一条完全避开 S 的简单路径

$$v_0 - v_1 - \cdots - v_m, \quad v_0 \in A, \quad v_m \in B.$$

取任意 $J \neq 0$ 。对路径上的边设

$$\psi_{\{v_{r-1}, v_r\}}(x_{v_{r-1}}, x_{v_r}) = \exp(J x_{v_{r-1}} x_{v_r}), \quad r = 1, \dots, m,$$

其余所有边势均取常数 1。每个势都严格为正, 有限状态空间又保证 $0 < Z < \infty$, 所以这确实定义了所要求的模型。

所有非恒定势都位于选定路径上。即使图中还有连接路径节点与路径外节点的边, 这些边势也已被设为常数; 因此完整分布分成路径分布与路径外均匀分布的乘积。对路径外变量求和只产生常数因子, 给定同样位于路径外的 $\mathbf{X}_S$ 也不会改变路径上的联合分布。特别地, 对每个 $\mathbf{s}$ 都有

$$p(x_{v_0}, \dots, x_{v_m} \mid \mathbf{s}) = \frac{1}{2} \prod_{r=1}^m \frac{\exp(J x_{v_{r-1}} x_{v_r})}{2 \cosh J}.$$

令 $\rho = \tanh J \neq 0$ 。上式把路径写成初始状态均匀的二状态 Markov 链, 其一步条件均值为

$$\mathbb{E}[X_{v_r} \mid X_{v_{r-1}}] = \rho X_{v_{r-1}}.$$

逐步取条件期望可得

$$\mathbb{E}[X_{v_0} X_{v_m} \mid X_S = \mathbf{s}] = \rho^m \neq 0, \quad \mathbb{E}[X_{v_0} \mid \mathbf{s}] = \mathbb{E}[X_{v_m} \mid \mathbf{s}] = 0.$$

所以路径端点在给定 $\mathbf{X}_S$ 后仍然依赖。若 $X_A \perp\!\!\!\perp X_B \mid X_S$ 成立, 条件独立性的分解性质会推出 $X_{v_0} \perp\!\!\!\perp X_{v_m} \mid X_S$, 与上式矛盾。这个构造只证明不分离时存在一个见证分布; 把 J 取为零就会得到额外独立性, 说明不分离本身并不强迫每个模型都相关。 ■

18.4 无向图中的因子分解

独立性说明哪些信息可以忽略，还没有给出配置的概率。要建立具体分布，可以为局部变量组合赋予非负权重，再把这些权重合成为全局概率。关键问题有两个：什么样的局部组合符合图结构，以及合成后的函数是否真的能够归一化。

18.4.1 因子分解的定义

前面用于构造分布的势函数为局部配置给出相容程度。现在把这种局部权重与图中的团对应起来：设 c 为图中团的一个族， $\psi_C(\mathbf{x}_C)$ 是定义在团 C 上的有限非负函数。若存在 $0 < Z < \infty$ 使

$$p(\mathbf{x}) = \frac{1}{Z} \prod_{C \in c} \psi_C(\mathbf{x}_C), \quad (18.6)$$

就称 p 按照 g 进行团因子分解。势函数的自变量只能属于相应的团，但可以实际依赖团内的每个变量。

对于离散变量，配分函数将所有完整配置的权重相加，给出全局归一化常数：

$$Z = \sum_{\mathbf{x} \in \mathcal{X}} \prod_{C \in c} \psi_C(\mathbf{x}_C), \quad \mathcal{X} = \prod_{i \in V} \mathcal{X}_i. \quad (18.7)$$

在有限状态空间上，有限势函数保证 Z 有限，但仍须排除所有配置权重都为零的情形。若状态空间可数无限，则还必须检查级数收敛。每个 ψ_C 无需对自己的变量求和为 1；把势函数各自归一化也不能免去全局的 Z ，因为不同团通常共享变量。

局部势容易求值，不表示全局归一化容易完成。若 d 个变量各有 q 个状态，直接计算式 (18.7) 就要累加 q^d 个配置的权重。例如 20 个二值变量已经有 $2^{20} = 1048576$ 种配置。这是直接枚举的成本；链、树或树宽较小的图可以利用局部结构复用求和，后面的精确推断章节将展开这种计算。

单节点条件概率则有一个不同的简化。记 $w(\mathbf{x}) = \prod_{C \in c} \psi_C(\mathbf{x}_C)$ ，固定其余变量的取值 $\mathbf{x}_{-i} = \mathbf{x}_{V \setminus \{i\}}$ ，且要求 $p(\mathbf{x}_{-i}) > 0$ 。按条件概率定义，

$$\begin{aligned} p(x_i | \mathbf{x}_{-i}) &= \frac{w(x_i, \mathbf{x}_{-i})/Z}{\sum_{a \in \mathcal{X}_i} w(a, \mathbf{x}_{-i})/Z} \\ &= \frac{\prod_{C \ni i} \psi_C(\mathbf{x}_C)}{\sum_{a \in \mathcal{X}_i} \prod_{C \ni i} \psi_C(a, \mathbf{x}_{C \setminus \{i\}})}. \end{aligned} \quad (18.8)$$

共同的 Z 先在比值中约掉，不含 i 的势也因取值固定而约掉，剩下的分母只需枚举 X_i 的状态。式中 $\psi_C(a, \mathbf{x}_{C \setminus \{i\}})$ 表示把第 i 个变量置为 a ，其他变量保持给定值；二值节点的分母只有两项。这解释了为什么在给定其余全部变量时可以直接做局部归一化。若只给定少数证据、还需对许多隐藏变

量求和，约去共同常数之后仍然可能留下困难的高维求和。

任意团都包含于某个极大团。把一个小团的势乘入包含它的某个极大团势，就能得到仅以极大团为索引的分解，不改变联合分布。每个小团只需分配一次，不能在所有包含它的极大团中重复相乘。因而“按团分解”与“按极大团分解”描述同一分布族，差别在于局部参数如何组织。三节点团上的一般势却不能总被单点势和成对势替代；团所允许的高阶相互作用是真正的表达能力。

当势严格为正时，可以把乘积改写为指数形式。令 $\varepsilon_C = -\log \psi_C$ ，并定义**能量函数**（energy function） $E(\mathbf{x}) = \sum_C \varepsilon_C(\mathbf{x}_C)$ ，便有

$$p(\mathbf{x}) = Z^{-1} \exp[-E(\mathbf{x})].$$

能量越低，对应的未归一化权重越大。若某个势为零，可以用 $\varepsilon_C = +\infty$ 表达被禁止的配置，但涉及对数差分的证明不能再把这些无穷值当成普通实数运算。

对于连续变量，沿用第 17.4.1 节的密度约定，指定各坐标空间上的 σ 有限基准测度 μ_i 及其乘积测度 $\mu = \bigotimes_{i \in V} \mu_i$ ；实数变量通常采用 Lebesgue 测度。势须可测，乘积须满足

$$0 < Z = \int_{\mathbf{x}} \prod_{C \in \mathcal{C}} \psi_C(\mathbf{x}_C) d\mu(\mathbf{x}) < \infty. \quad (18.9)$$

式 (18.6) 此时才是归一化密度。单个势可以不可积，多个势的乘积仍可能可积；反过来，势处处为正也不能保证积分有限，例如 $\mathbb{R}^d$ 上的常数势乘积。这些区别在高斯参数化中会具体表现为精度矩阵的正定性要求。

示例 18.13 四节点环上的相容分数 令 $X_i \in \{0, 1\}$ ，四条边上的势相同：

$$\psi_{\{i,j\}}(x_i, x_j) = \begin{cases} 2, & x_i = x_j, \\ 1, & x_i \neq x_j. \end{cases}$$

每条相同状态的边把配置权重乘以 2。图 18.5 以 $\mathbf{x} = (0, 0, 1, 1)$ 为例，逐条读取四个边势，先得到未归一化权重 4，再除以 $Z = 82$ 得到概率 $2/41$ 。沿环一周，状态改变的次数必须为偶数，所以相同边数只能为 4, 2, 0。表 18.1 按这三种情况汇总全部 16 个配置的权重。因而 $Z = 32 + 48 + 2 = 82$ ，另有 $p(0, 0, 0, 0) = 16/82 = 8/41$ 和 $p(0, 1, 0, 1) = 1/82$ 。这些数值来自人为指定的势，不是实测统计。




图 18.5 四节点环上单个配置 $\mathbf{x} = (0, 0, 1, 1)$ 的概率计算。边标签逐条给出势值；相乘得到未归一化权重 4，再除以全部 16 个配置共同确定的配分函数 $Z = 82$ ，得到概率 $2/41$ 。

相同边数	配置数	单个权重	总权重
4	2	16	32
2	12	4	48
0	2	1	2

表 18.1 四节点二值环的配置权重。相同状态的边贡献势值 2，不同状态的边贡献 1；总权重之和为配分函数 82。

18.4.2 从因子分解到条件独立性

定理 18.11 已经陈述团分解上的分离可靠性。现在补全证明：关键不是分别检查每条缺边，而是利用删除 S 后的连通分量，把所有团因子分到分离集的两侧。

定理 18.11 的证明。取被 S 分离的两两不交集合 A, B, S ，只需考虑 A, B 均非空的情形。令 U 为 $\mathcal{G}[V \setminus S]$ 中所有与 A 相交的连通分量的并，令 $W = V \setminus (S \cup U)$ 。于是 $A \subseteq U$ 、 $B \subseteq W$ ，并且 U 与 W 之间没有边。

任何团都不能同时包含 U 与 W 中的节点，否则团内这两个节点之间必须有边，与二者没有边矛盾。因此，每个团或者完全位于 S ，或者除 S 外的节点全部落在 U ，或者全部落在 W 。将三类势分别相乘，可以写成

$$p(\mathbf{u}, \mathbf{w}, \mathbf{s}) = Z^{-1} h(\mathbf{s}) f(\mathbf{u}, \mathbf{s}) g(\mathbf{w}, \mathbf{s}), \quad (18.10)$$

其中 $\mathbf{u}, \mathbf{w}, \mathbf{s}$ 分别是 $\mathbf{X}_U, \mathbf{X}_W, \mathbf{X}_S$ 的取值，空乘积取 1。

在离散情况下，令 $F(\mathbf{s}) = \sum_{\mathbf{u}} f(\mathbf{u}, \mathbf{s})$ 、 $G(\mathbf{s}) = \sum_{\mathbf{w}} g(\mathbf{w}, \mathbf{s})$ ；连续情况下把这两个和换成相应乘积测度下的积分。只考虑 $p_S(\mathbf{s})$ 有限且严格为正的取值：离散时它们包括全部正概率条件事件，连续时它们承载全部 $\mathbf{X}_S$ 概率。此时 $h(\mathbf{s})$ 必为正，否则式 (18.10) 在该条件下恒为零。非负性允许用 Tonelli 定理交换积分并分离乘积，得到

$$p_S(\mathbf{s}) = Z^{-1} h(\mathbf{s}) F(\mathbf{s}) G(\mathbf{s}).$$

若 $F(\mathbf{s})$ 或 $G(\mathbf{s})$ 为零, 联合积分就为零; 若其中一个无穷而另一个为正, 联合积分就无穷。因此在上述条件取值上, $F(\mathbf{s})$ 与 $G(\mathbf{s})$ 均有限且严格为正, 可以归一化为

$$p(\mathbf{u}, \mathbf{w} | \mathbf{s}) = \frac{f(\mathbf{u}, \mathbf{s})}{F(\mathbf{s})} \frac{g(\mathbf{w}, \mathbf{s})}{G(\mathbf{s})}. \quad (18.11)$$

右侧两个函数各自归一化, 所以 $\mathbf{X}_U \perp \mathbf{X}_W | \mathbf{X}_S$ 。

还需处理未查询变量。分别对 $U \setminus A$ 与 $W \setminus B$ 的变量求和或积分, 式 (18.11) 仍分成一个只含 $\mathbf{x}_A, \mathbf{s}$ 的函数与一个只含 $\mathbf{x}_B, \mathbf{s}$ 的函数, 两者就是对应的条件边缘分布。因此 $\mathbf{X}_A \perp \mathbf{X}_B | \mathbf{X}_S$, 证明了任意分离关系所要求的独立性。 ■

证明只在实际有概率质量或密度的条件取值上归一化, 没有除以某个可能为零的团势, 也没有取对数。因此允许结构性零概率; 结合定理 18.6, 团分解同时蕴含局部和成对性质。这里从因子分解直接推出全局性质, 没有调用 Hammersley-Clifford 逆向结论, 后面的等价证明因而不会形成循环。

在示例 18.13 中, 固定 $X_2 = x_2, X_4 = x_4$, 四个边势恰好分为

$$\begin{aligned} f(x_1) &= \psi_{\{1,2\}}(x_1, x_2) \psi_{\{1,4\}}(x_1, x_4), \\ g(x_3) &= \psi_{\{2,3\}}(x_2, x_3) \psi_{\{3,4\}}(x_3, x_4). \end{aligned}$$

当 $x_2 = x_4 = 0$ 时, $f(0) = g(0) = 4$, $f(1) = g(1) = 1$, 所以

$$p(x_1, x_3 | 0, 0) = \frac{1}{25} \begin{pmatrix} 16 & 4 \\ 4 & 1 \end{pmatrix}_{x_1+1, x_3+1}.$$

矩阵的行、列分别按 0, 1 排列, 其条件边缘均为 $(4/5, 1/5)$, 外积正好得到该矩阵。当 $x_2 = 0, x_4 = 1$ 时, f 与 g 的两种取值都为 2, 条件联合分布变成四个 $1/4$ 。邻居的取值改变了两端的条件概率, 却没有改变给定邻居后的独立性。

18.4.3 从条件独立性到因子分解

逆向问题更强: 仅知道缺边所要求的条件独立性, 能否找出一组团势, 精确重建整个联合分布? 下述证明采用 Gill 笔记中的基准配置构造, 把对数概率拆成局部项, 再证明非团项消失²。

Hammersley-Clifford 定理回答了有限离散严格正分布下的问题。这里严格正是指对完整笛卡尔积 $\mathcal{X} = \prod_i \mathcal{X}_i$ 中的每个配置都有 $p(\mathbf{x}) > 0$, 而不是只对已经保留的支持集说概率为正。定理 18.9 已经处理三种 Markov 性质之间的关系, 下面只需把其中任一种性质与团因子分解联系起来。

² R. D. Gill, *The Hammersley-Clifford Theorem*, Mathematical Institute, University of Leiden, Oct. 4, 2011, URL: <https://pub.math.leidenuniv.nl/~gillrd/teaching/graphical/hammersley-clifford.pdf> (visited on 10/03/2026)

定理 18.14 有限离散 Hammersley-Clifford 定理 设 $\mathcal{G} = (V, E)$ 为有限简单无向图，每个节点 $i \in V$ 对应取值于有限非空状态空间 $\mathcal{X}_i$ 的随机变量 X_i 。令 p 为 $\mathbf{X} = (X_i)_{i \in V}$ 在乘积状态空间 $\mathcal{X} = \prod_{i \in V} \mathcal{X}_i$ 上的联合质量函数，并且 $p(\mathbf{x}) > 0$ 对所有 $\mathbf{x} \in \mathcal{X}$ 成立。则以下四个条件等价： p 满足相对于 $\mathcal{G}$ 的全局 Markov 性质； p 满足相对于 $\mathcal{G}$ 的局部 Markov 性质； p 满足相对于 $\mathcal{G}$ 的成对 Markov 性质； p 能按 $\mathcal{G}$ 的团分解。分解中的势可以全部取为严格正值。

证明. 由定理 18.11，团分解蕴含全局 Markov 性质；由定理 18.9，三种 Markov 性质在当前条件下等价。因此只需从成对性质构造团分解。任取基准配置 $\mathbf{x}^\circ \in \mathcal{X}$ ，对每个 $D \subseteq V$ 定义

$$\mathbf{x}^D = (\mathbf{x}_D, \mathbf{x}_{V \setminus D}^\circ), \quad L_D(\mathbf{x}_D) = \log p(\mathbf{x}^D).$$

也就是说，仅让 D 中的坐标使用当前值，其余坐标固定在基准值。严格正性保证所有这些对数都是有限实数。

对每个 $D \subseteq V$ 构造

$$\phi_D(\mathbf{x}_D) = \sum_{B \subseteq D} (-1)^{|D|-|B|} L_B(\mathbf{x}_B). \quad (18.12)$$

其中 $\phi_\emptyset = \log p(\mathbf{x}^\circ)$ 。这个交替加减式称为基准配置上的 **Möbius 分解** (Möbius decomposition)：它从 D 的联合变化中减去所有更小子集已经解释的部分。例如

$$\begin{aligned} \phi_{\{i\}} &= L_{\{i\}} - L_\emptyset, \\ \phi_{\{i,j\}} &= L_{\{i,j\}} - L_{\{i\}} - L_{\{j\}} + L_\emptyset. \end{aligned}$$

这组局部项确实可以重建对数概率。对所有 D 求和并交换有限求和次序，有

$$\begin{aligned} \sum_{D \subseteq V} \phi_D(\mathbf{x}_D) &= \sum_{B \subseteq V} L_B(\mathbf{x}_B) \sum_{D: B \subseteq D \subseteq V} (-1)^{|D|-|B|} \\ &= L_V(\mathbf{x}_V) = \log p(\mathbf{x}). \end{aligned} \quad (18.13)$$

第二个等号的理由是：固定 B 后，内层系数为 $(1-1)^{|V|-|B|}$ ；当 $B \neq V$ 时为零，当 $B = V$ 时唯一一项为 1。因而除了完整配置的对数概率，其他项恰好抵消。

接下来利用成对 Markov 性质证明：若非空子集 D 不是团，则 ϕ_D 恒为零。取 D 中一对不相邻节点 i, j ，记 $R = V \setminus \{i, j\}$ 。给定任意 $\mathbf{x}_R$ ，条件独

立性使二元条件概率成为外积，故对任意 $a, a' \in \mathcal{X}_i$ 和 $b, b' \in \mathcal{X}_j$,

$$\begin{aligned} p(a, b, \mathbf{x}_R) p(a', b', \mathbf{x}_R) \\ = p(a, b', \mathbf{x}_R) p(a', b, \mathbf{x}_R). \end{aligned} \quad (18.14)$$

这里已把共同的条件归一化因子消去。取 $a = x_i, a' = x_i^\circ, b = x_j, b' = x_j^\circ$, 再令 R 中某个子集 B 使用当前值、其余使用基准值，取对数得到

$$L_{B \cup \{i, j\}} - L_{B \cup \{i\}} - L_{B \cup \{j\}} + L_B = 0.$$

它表达的是：在其他坐标固定后，同时改变两个非邻居，不会产生超出分别改变二者的额外交互项。

令 $T = D \setminus \{i, j\}$ ，把式 (18.12) 中的子集按是否包含 i, j 分为四组，便有

$$\begin{aligned} \phi_D = \sum_{B \subseteq T} (-1)^{|T|-|B|} (L_{B \cup \{i, j\}} - L_{B \cup \{i\}} \\ - L_{B \cup \{j\}} + L_B) = 0. \end{aligned} \quad (18.15)$$

括号中的每一项组合都为零，所以任何包含非邻接对的交互项都消失，而不只是二阶项消失。

记 $\mathcal{C}_{\text{all}}$ 为所有非空团组成的族。将剩下的团函数指数化，令 $\psi_C = \exp(\phi_C) > 0$ ，由式 (18.13) 得到

$$p(\mathbf{x}) = \exp(\phi_\emptyset) \prod_{C \in \mathcal{C}_{\text{all}}} \psi_C(\mathbf{x}_C).$$

对 $\mathbf{x}$ 求和可知，乘积的配分函数为 $Z = \exp(-\phi_\emptyset)$ ，有限且严格为正。再把小团势并入极大团即可得到所需分解。 ■

证明中，Möbius 恒等式只是有限集合上的代数；图结构通过“非团项为零”进入。严格正性承担了两个具体任务：保证每个其余变量配置都能作为条件，保证矩形等式可以取有限对数。它是这里统一得到逆向结论的充分条件，不是所有可分解分布都必须满足的条件。下面沿用四节点环，构造一个满足全部 Markov 独立性却不能团分解的分布，直接检验去掉严格正性后会失去哪个方向。

示例 18.15 满足全局 Markov 性质却不能团分解 仍使用四节点环，但改用以下人工构造的分布。取相互独立的公平二值变量 U, V ，令

$$X_1 = U, \quad X_2 = V, \quad X_3 = U \oplus V, \quad X_4 = U,$$

其中 $\oplus$ 为模 2 加法。表 18.2 列出全部正概率配置，其余均为零。

x_1	x_2	x_3	x_4	概率
0	0	0	0	1/4
0	1	1	0	1/4
1	0	1	1	1/4
1	1	0	1	1/4

表 18.2 四节点环上不满足严格正性的分布。任意一对对角节点的取值均能确定整行，但边上的局部取值不足以刻画这个全局支持集。

给定 (X_2, X_4) 就确定 (U, V) ，所以 X_1 与 X_3 在此条件下都是常量，二者条件独立。给定 (X_1, X_3) 同样确定 (U, V) ，所以 $X_2 \perp X_4 \mid (X_1, X_3)$ 。在四节点环上，删除一个节点仍然连通；两组非空节点要被分离，只能是两个对角节点被另外两个对角节点分离。因此刚才两个条件独立性覆盖全部非平凡分离，该分布满足全局 Markov 性质，也满足局部和成对性质。

假设它能够按四条边分解；单点势可以先并入边势。考察被禁止的配置 $\mathbf{y} = (0, 0, 1, 0)$ 。它在边 $\{1, 2\}$ 上的局部取值 $(0, 0)$ 出现于正概率配置 $(0, 0, 0, 0)$ ，在边 $\{2, 3\}$ 上的 $(0, 1)$ 出现于 $(1, 0, 1, 1)$ ，在边 $\{3, 4\}$ 上的 $(1, 0)$ 出现于 $(0, 1, 1, 0)$ ，在边 $\{1, 4\}$ 上的 $(0, 0)$ 又出现于 $(0, 0, 0, 0)$ 。正概率配置中的每个边势值都必须严格为正，因此 $\mathbf{y}$ 的四个边势值也都为正，分解会推出 $p(\mathbf{y}) > 0$ ，与定义矛盾。

图 18.6 把这四个局部取值放回环上。每条边都见过相应组合，但四条边共同拼出的完整配置却未出现在表 18.2 中。




图 18.6 零概率破坏逆向分解的反例。左侧节点给出被禁止配置 $\mathbf{y} = (0, 0, 1, 0)$ ，边旁的每个局部取值对都曾在正概率配置中出现。右侧 2×2 支持表按 (U, V) 列出四个正概率配置，并直接标出其余 12 个配置概率为 0。若存在非负边势分解， $\mathbf{y}$ 对应的四个边势值就必须都为正，其乘积也为正，与 $p(\mathbf{y}) = 0$ 矛盾。

这个反例不仅表明对数证明无法处理零值，而且直接排除了任何非负团势分解。独立性成立是因为条件变量已经把未观测变量完全确定；团势却只能看到局部投影，无法禁止一个在每条边上都被允许、但整体上被

禁止的组合。与此同时，某些零概率分布当然可以分解，例如直接用边势 $\mathbf{1}\{x_i = x_j\}$ 施加相等约束。不能把“逆向结论可能失效”误写成“有零值就一定不能分解”。

连续密度的逆向结论需要说明测度与所采用的密度版本。仅有 $p > 0$ 几乎处处时，任意固定的坐标截面都可能落在可随意修改的零测集上；直接在该截面取 L_D 并沿用上面的逐点证明，论证就不完整。一般可测空间上的版本需要用测度论处理这些例外集合，不能把每个“几乎处处”直接删去³。

³ S. L. Lauritzen, *Graphical Models*, Clarendon Press, 1996

一个足以直接使用的连续版本如下：令 $\mathcal{X} = \prod_i I_i$ ，每个 I_i 是非空开区间，基准测度为 Lebesgue 乘积测度；设 p 是其上的连续、处处严格正、积分为 1 的密度。若 p 满足成对 Markov 性质，则存在连续严格正的团势，使其团乘积等于 p 乘以一个有限正数。其证明只需补上离散证明没有遇到的一步：条件独立性使式 (18.14) 对 $(a, a', b, b', \mathbf{x}_R)$ 几乎处处成立；两侧之差是开乘积域上的连续函数，如果某一点不为零，就会在一个有正测度的邻域内不为零，产生矛盾。因此矩形等式处处成立，可以任选域内基准配置，再逐式应用有限节点集合上的 Möbius 分解。所得团乘积与 p 成正比，其积分有限性由 p 的归一化保证。

这里连续性是一组方便核验的充分条件，不声称它是所有可测版本的必要条件。若还希望对 $\log p$ 求混合偏导，则须进一步要求相应可微性，例如二阶连续可微；若预先选定一族光滑或神经参数化势，仍须单独检查其乘积可积。分解定理保证存在合适的团函数，不保证任意给出的团函数、任意参数或任意函数空间限制都定义合法密度。

18.5 局部参数化

因子分解确定了局部函数应当依附于哪些团，但没有规定这些函数怎样表示。离散模型与连续模型需要不同的参数化，同时都必须满足全局可归一化条件。

18.5.1 离散变量的局部参数化

等价定理给出了可分解性，实际建模还需要选择怎样表示每个势。单点势 $\psi_{\{i\}}(x_i)$ 表达某个状态自身的偏好，成对势 $\psi_{\{i,j\}}(x_i, x_j)$ 表达两个状态的相容关系，高阶团势则表达多个变量共同取值时的额外作用。若每个变量有 q 个状态，一个一般的 k 节点团势表需要存储 q^k 个值，因此高阶表达能力伴随局部存储成本。

对严格正势，可以选取团内特征 $f_{C,r}(\mathbf{x}_C)$ ，用它们线性表示对数势。特征可以是“两个状态相同”的指示函数，也可以是某个具体团配置的指示

函数:

$$\log \psi_C(\mathbf{x}_C; \boldsymbol{\theta}) = \sum_r \theta_{C,r} f_{C,r}(\mathbf{x}_C).$$

把全部特征与系数分别组成向量 $\mathbf{f}(\mathbf{x})$ 与 $\boldsymbol{\theta}$, 得到**对数线性模型** (log-linear model), 即对数概率由特征的线性组合与归一化项组成:

$$\begin{aligned} p_{\boldsymbol{\theta}}(\mathbf{x}) &= \exp\{\boldsymbol{\theta}^\top \mathbf{f}(\mathbf{x}) - A(\boldsymbol{\theta})\}, \\ A(\boldsymbol{\theta}) &= \log \sum_{\mathbf{x}} \exp\{\boldsymbol{\theta}^\top \mathbf{f}(\mathbf{x})\}. \end{aligned} \quad (18.16)$$

这也是一个**指数族** (exponential family): 参数通过特征内积进入指数, $A = \log Z$ 统一保证归一化。若为每个团配置设置指示特征, 就能表示任意严格正团势; 采用更少的共享特征则是在图约束之外进一步限制模型族⁴。

例如**Ising 模型**使用 $x_i \in \{-1, +1\}$, 把状态自身的偏好与相邻状态的乘积写入对数权重:

$$p(\mathbf{x}) = \frac{1}{Z} \exp \left\{ \sum_i h_i x_i + \sum_{\{i,j\} \in E} J_{i,j} x_i x_j \right\}. \quad (18.17)$$

$h_i > 0$ 偏向 $+1$, $J_{i,j} > 0$ 偏向两个状态相同, $J_{i,j} < 0$ 偏向不同; 它们表达相容分数, 不是边缘概率。示例 18.13 中的状态用 $s_i = 2x_i - 1$ 换成 $\{-1, +1\}$ 后, 有

$$\psi_{\{i,j\}}(x_i, x_j) = \sqrt{2} \exp \left\{ \frac{\log 2}{2} s_i s_j \right\}.$$

四个 $\sqrt{2}$ 的乘积是常数, 能够并入 Z ; 所以该教学分布正是零单点偏好、耦合 $J_{i,j} = (\log 2)/2$ 的 Ising 环。

Potts 模型允许 $x_i \in \{1, \dots, q\}$, 常用成对势为

$$\psi_{\{i,j\}}(x_i, x_j) = \exp\{J_{i,j} \mathbf{1}\{x_i = x_j\}\}.$$

它奖励或惩罚相同类别, 不要求类别编号具有数值距离。高阶特征可以表达成对项之外的偏好, 例如对三个取值为 $\{-1, +1\}$ 的变量, 在三节点团上加入对数势 $\lambda x_i x_j x_k$, 就能奖励乘积为正或为负的配置。若图中没有该团, 直接加入这样的势一般就改变了图的独立性承诺。Ising、Potts 及其他能量模型的具体建模与计算将在第 27 章展开。

局部参数并不意味着学习可以完全局部进行。对 n 个完整、独立同分布样本向量 $\mathbf{x}_1, \dots, \mathbf{x}_n$, 令 $\bar{\mathbf{f}} = n^{-1} \sum_{k=1}^n \mathbf{f}(\mathbf{x}_k)$, 平均对数似然及其梯度为

$$\begin{aligned} \ell(\boldsymbol{\theta}) &= \boldsymbol{\theta}^\top \bar{\mathbf{f}} - A(\boldsymbol{\theta}), \\ \nabla_{\boldsymbol{\theta}} \ell(\boldsymbol{\theta}) &= \bar{\mathbf{f}} - \mathbb{E}_{p_{\boldsymbol{\theta}}}[\mathbf{f}(\mathbf{X})]. \end{aligned} \quad (18.18)$$

⁴ M. J. Wainwright, M. I. Jordan, *Graphical Models, Exponential Families, and Variational Inference* In Foundations and Trends in Machine Learning, 2008, vol. 1, no. 1-2, pp. 1-305

第二式由对有限和中的指数逐项求导得到。数据给出经验特征平均，参数更新还要计算当前联合分布下的特征平均，因此学习反复调用推断。式 (18.8) 中的局部归一化不能替代这里的全局期望；树结构可以通过局部消息计算，而一般含环图的代价取决于消元产生的中间因子。第 20 章与第 24 章分别展开推断与参数估计，这里已经能看到配分函数如何把二者联系起来。

18.5.2 连续变量的局部参数化

连续变量也可以用局部相容关系建模，但参数不能任意选择。最直接的例子是二次能量：它既允许精确计算，又能清楚展示“局部势为正”与“全局密度存在”的区别。**高斯 Markov 随机场** (Gaussian Markov random field, GMRF) 是以无向图描述条件独立性的联合高斯分布。本节讨论 $\mathbb{R}^d$ 上相对于 Lebesgue 测度的非退化情形，设

$$p(\mathbf{x}) = Z^{-1} \exp \left\{ -\frac{1}{2} \mathbf{x}^\top \mathbf{Q} \mathbf{x} + \mathbf{h}^\top \mathbf{x} \right\}, \quad (18.19)$$

$$\mathbf{Q} = \mathbf{Q}^\top > 0.$$

其中 $\mathbf{Q}$ 是**精度矩阵** (precision matrix)，即协方差矩阵的逆； $\mathbf{h} \in \mathbb{R}^d$ 是线性项系数。配方得到均值 $\mathbf{m} = \mathbf{Q}^{-1} \mathbf{h}$ 与协方差 $\Sigma = \mathbf{Q}^{-1}$ ，并给出

$$Z = (2\pi)^{d/2} \det(\mathbf{Q})^{-1/2} \exp \left\{ \frac{1}{2} \mathbf{h}^\top \mathbf{Q}^{-1} \mathbf{h} \right\}. \quad (18.20)$$

这说明正定性足以保证有限归一化。它也对这种全空间二次能量是必要的：沿 $\mathbf{Q}$ 的特征向量作正交坐标变换后，若某个特征值为负，对应方向的指数按正二次项增长；若特征值为零，沿该方向只剩线性指数或常数，两者在整条实轴上都不可积。

图结构来自二次型的展开：

$$-\frac{1}{2} \mathbf{x}^\top \mathbf{Q} \mathbf{x} + \mathbf{h}^\top \mathbf{x} = \sum_i \left(-\frac{1}{2} Q_{i,i} x_i^2 + h_i x_i \right) - \sum_{i < j} Q_{i,j} x_i x_j.$$

这里 $Q_{i,j}$ 为 $\mathbf{Q}$ 的第 (i, j) 个元素。单点项定义单点势，非零的交叉项定义边势 $\exp(-Q_{i,j} x_i x_j)$ 。这个边势本身未必可积，也不是二元概率密度；要求可积的是全部势的乘积。若所有缺边均满足 $Q_{i,j} = 0$ ，就得到了图上的团分解。

在高斯情形，精度零元与给定其余变量后的独立性还是双向关系：

$$Q_{i,j} = 0 \iff X_i \perp X_j \mid \mathbf{X}_{V \setminus \{i,j\}}, \quad i \neq j. \quad (18.21)$$

为看清逆向，固定其余变量后， (X_i, X_j) 的条件分布仍为高斯，其精度是主

子矩阵

$$\begin{pmatrix} Q_{i,i} & Q_{i,j} \\ Q_{i,j} & Q_{j,j} \end{pmatrix}.$$

正定性保证 $Q_{i,i}Q_{j,j} - Q_{i,j}^2 > 0$ 。将这个 2×2 矩阵求逆，条件协方差的非对角元素为

$$-\frac{Q_{i,j}}{Q_{i,i}Q_{j,j} - Q_{i,j}^2}.$$

联合高斯的两个分量独立当且仅当协方差为零，所以得到式 (18.21)。注意， $\Sigma_{i,j} = 0$ 刻画的是边缘独立性， $Q_{i,j} = 0$ 刻画的是给定其余全部变量后的条件独立性；不能用稀疏协方差替代稀疏精度。

固定除 i 外的坐标并对 x_i 配方，还得到局部条件分布

$$X_i \mid \mathbf{x}_{V \setminus \{i\}} \sim \mathcal{N}\left(\frac{h_i - \sum_{j \neq i} Q_{i,j} x_j}{Q_{i,i}}, \frac{1}{Q_{i,i}}\right). \quad (18.22)$$

非邻居的系数为零，所以条件均值只依赖邻居。这一公式也揭示了从局部条件分布反推联合分布的约束。若给出条件方差 $1/\tau_i$ 与条件均值 $\alpha_i + \sum_{j \neq i} \beta_{i,j} x_j$ ，则必须有 $Q_{i,i} = \tau_i$ 、 $Q_{i,j} = -\tau_i \beta_{i,j}$ 以及 $h_i = \tau_i \alpha_i$ ，因此至少要求 $\tau_i \beta_{i,j} = \tau_j \beta_{j,i}$ 使 Q 对称，还要求整个 Q 正定。仅有所有 $\tau_i > 0$ 并不足够；若不满足兼容条件，这些逐点看来合法的高斯条件分布可能不属于任何所要求的联合高斯分布⁵。

四节点环的一个可核验高斯实例是 $\mathbf{h} = \mathbf{0}$ 及

$$Q = \begin{pmatrix} 3 & -1 & 0 & -1 \\ -1 & 3 & -1 & 0 \\ 0 & -1 & 3 & -1 \\ -1 & 0 & -1 & 3 \end{pmatrix}.$$

若 L 是该环的图 Laplacian 矩阵，即对角为节点度数、相邻处为 -1 、其余为 0 ，则 $Q = I + L$ 。对任意非零 $\mathbf{v}$,

$$\mathbf{v}^\top Q \mathbf{v} = \sum_i v_i^2 + \sum_{\{i,j\} \in E} (v_i - v_j)^2 > 0,$$

所以它确实定义合法密度。其逆矩阵为

$$\Sigma = \frac{1}{15} \begin{pmatrix} 7 & 3 & 2 & 3 \\ 3 & 7 & 3 & 2 \\ 2 & 3 & 7 & 3 \\ 3 & 2 & 3 & 7 \end{pmatrix}.$$

$Q_{1,3} = 0$ 而 $\Sigma_{1,3} = 2/15$ ：两个对角节点边缘相关，但给定另外两个节点后

⁵ H. Rue, L. Held, *Gaussian Markov Random Fields: Theory and Applications*, Chapman and Hall/CRC, 2005, 1st ed.

独立。节点 1 的条件均值是 $(x_2 + x_4)/3$ ，条件方差是 $1/3$ ，与 x_3 无关。这与离散环例子具有相同的图语义，但局部概率形式不同。

若把上例的 Q 换成 L ，令 $\mathbf{1}$ 为全 1 向量，则 $L\mathbf{1} = \mathbf{0}$ ，能量对所有坐标同时平移不变，积分沿常数方向发散。奇异的半正定精度不能定义 $\mathbb{R}^d$ 上的非退化归一化高斯密度。所谓**内蕴高斯 Markov 随机场** (intrinsic GMRF) 使用的是这类未完全归一化的模型；可以通过约束到适当子空间并指定该子空间上的测度来构造概率分布，或在适当条件下与似然结合得到可归一化的后验，但都不是把奇异精度直接代入式 (18.20)。退化高斯在子空间上的条件独立性也不能无条件沿用上述逆矩阵判据。

势函数还可以随外部输入变化。若 $\mathbf{x}$ 是已知输入、 $\mathbf{y}$ 是需要预测的输出，**条件 Markov 网络** (conditional Markov network) 直接定义

$$p_{\theta}(\mathbf{y} | \mathbf{x}) = \frac{1}{Z_{\theta}(\mathbf{x})} \prod_{C \in \mathcal{C}} \psi_C(\mathbf{y}_C; \mathbf{x}, \theta). \quad (18.23)$$

此时图的节点对应输出变量， $\mathbf{x}$ 作为固定条件可以进入每个势；归一化只对 $\mathbf{y}$ 求和或积分，并要求每个被使用的输入下 $0 < Z_{\theta}(\mathbf{x}) < \infty$ 。模型没有由此定义输入的联合分布。输出可以离散也可以连续，若采用高斯输出，就要保证相应 $Q(\mathbf{x})$ 对每个允许输入均对称正定。条件随机场等具体形式见第 27 章。

局部参数化的边界现在可以明确说明。改变一个势通常会改变 Z ，因而改变多个配置乃至远处变量的边缘概率；“参数放在局部”不等于“分布变化局限于局部”。不同势也可能表示同一分布：乘以一个正常数可被 Z 吸收，而两个共享节点的团之间可以把一个正函数乘入一侧、除到另一侧，使总乘积保持不变。因此参数唯一性需要额外约定，不能由图本身保证。

计算成本同样取决于全局组织方式。高阶团增大局部状态表，环则可能使消元产生更大的中间团；并非一出现环就无法精确计算，四节点环仍可直接核算，但大图的中间因子可能远大于原始势。高斯模型把求和积分化成线性方程求解与行列式计算，稠密情形通常需要 $O(d^3)$ 量级运算，稀疏图能否节省代价仍取决于消元时的填充。无论选择离散表格、二次能量还是输入依赖势，都要同时考虑表达能力、归一化条件与推断成本。

18.6 本章小结

无向图用条件节点是否阻断路径来承诺独立性。全局、局部与成对 Markov 性质分别约束集合分离、邻居 Markov 毯和缺边；一般分布中可靠的蕴含方向是全局到局部再到成对。团因子分解把分离集两侧的函数分别归一化，因此即使存在零概率配置，也仍能推出全局 Markov 性质。

对有限离散严格正分布，Möbius 分解与成对独立性使非团交互项消失，

从而得到 Hammersley–Clifford 逆向结论；零支持反例说明缺少严格正性时该方向可能失效，连续密度还须处理测度、密度版本与可积性。势函数与配分函数共同定义分布，离散和高斯参数也必须满足各自的合法性条件；图语义相同不代表参数化或计算代价相同。第 19 章将据此比较有向图、无向图和因子图的转换边界。

图表示的转换与因子图

同一个联合分布能否既画成有向图，又画成无向图？如果可以，换图以后，从图上读出的条件独立关系是否仍然相同？第 17 章和第 18 章分别建立了两类图的分解与分离规则，但这两个问题不能只靠删去箭头来回答。例如，用 F, H, A, S 分别表示故障、过热、报警与传感器失灵，则报警模型 $F \rightarrow H \rightarrow A \leftarrow S$ 中的 F 与 S 是独立根节点；观察报警 A 以后，两条原因路径却可能产生关联。无向图中的条件化只会阻断路径，无法用同一种规则直接复现这种变化。

比较表示时，需要分清三个对象：图结构经过什么转换，转换后的图声明哪些独立性，以及因子乘积怎样被重新组织。保持因子乘积不变，可以保持全部概率查询的答案，却未必使新图继续声明原来的全部独立性。因子图则把关注点进一步移到计算上：它显式记录每个因子需要哪些变量，并不与有向图模型、Markov 网络构成互斥的模型分类。本章先建立道德化与弦化这两类结构转换，再比较独立性和因子分解，最后说明因子图怎样保留局部计算结构。

以下图均为有限图，默认在同一节点集合 V 上比较，不引入辅助变量或潜变量。节点 i 对应标量随机变量 X_i ，节点集合 A 对应随机向量 $\mathbf{X}_A$ 。涉及条件概率表与数值计算时，变量取有限个离散值；连续情形的相应限制会在需要处说明。

19.1 有向图与无向图的结构转换

有向图转成无向图时，不能只擦掉箭头；无向图转成适合定向或消元的结构时，也不能任意添加边。前一种转换要保留共同子节点引起的父节点联系，后一种转换要让删点时留下的邻居已经成团。本节先定义这些操作本身，下一节再判断它们保留了哪些独立性。

19.1.1 骨架、祖先图与道德图

d-分离要检查路径中的碰撞点是否被自身或后代的观测激活。若只想回答一个给定查询，可以把这些判断转成一次无向分离，但所用的无向图必须随查询改变。

定义 19.1 骨架 设 $\mathcal{G} = (V, E)$ 为有限有向图。将每条有向边 $i \rightarrow j$ 替换为无向边 $\{i, j\}$ ，所得无向图称为 $\mathcal{G}$ 的**骨架** (skeleton)，记为 $\text{skel}(\mathcal{G})$ 。骨架保留节点与邻接关系，但丢弃全部箭头方向。

定义 19.2 祖先闭包 设 $\mathcal{G} = (V, E)$ 为有限有向图。对 $T \subseteq V$ ，定义

$$\text{an}^+(T) = T \cup \bigcup_{i \in T} \text{an}(i),$$

称为 T 的**祖先闭包** (ancestral closure)。若 $\text{an}^+(T) = T$ ，则称 T 为祖先集。

祖先闭包收集查询节点及所有能沿有向路径到达它们的节点，上标 + 强调集合包含查询节点自身。它只由有向图和节点集决定，尚未改变边的方向。

定义 19.3 查询的祖先图 设 $\mathcal{G} = (V, E)$ 为有限有向无环图。对两两不交且 A, B 非空的 $A, B, S \subseteq V$ ，令 $U = \text{an}^+(A \cup B \cup S)$ 。由 U 中的节点以及原图中两端都位于 U 的边组成的诱导子图 $\mathcal{G}[U]$ ，称为查询 $(A, B \mid S)$ 的**祖先图** (ancestral graph)。

查询的祖先图随 A, B, S 改变。它保留可能参与当前 d-分离判断的祖先结构，而不是固定取整个有向图。

定义 19.4 有向图的道德图 给定有限有向图 $\mathcal{H}$ ，先在每个节点的任意两个不同父节点之间补一条无向边，再把 $\mathcal{H}$ 中的全部有向边替换为无向边。由补边和原有有向边的无向版本共同组成的无向图称为 $\mathcal{H}$ 的**道德图** (moral graph)，记为 $\text{mor}(\mathcal{H})$ 。这一构造称为**道德化** (moralization)。

道德化把每个节点及其父节点连成团，使同一个局部条件因子的全部变量在无向图中两两相邻。祖先图负责选取与查询相关的节点，道德图负责把所保留的有向局部结构转成无向连接；两步的作用不能互换。

图 19.1 把四个操作分开显示。点线与 $\times$ 表示祖先闭包会删去的原节点和原边，带“补”标签的虚线表示道德化新增边，两种编码不共享线型语




图 19.1 查询祖先图的道德化过程。原有向图在报警节点 A 后接一个后代 D ；对查询 $F \perp S \mid A$ ，祖先闭包 $U = \{F, H, A, S\}$ 依赖端点和条件集，因而先删去不在 U 中的 D 及其关联边 $A \rightarrow D$ 。点线轮廓、点线有向边与 $\times$ 共同标识这些待删元素；随后在共同子节点 A 的父节点 H, S 之间加入的虚线专门编码补边，并用“补 $H - S$ ”直接标注。最后去掉原边的箭头得到查询祖先图的道德图；检测该查询时还要删除条件节点 A 。红色填充并配合“给定”文字标识条件节点。

义。读图时应先观察节点集合怎样随查询收缩，再观察 $H - S$ 补边怎样在去掉箭头后保留共同子节点的影响；若换成不包含 A 及其后代的查询，祖先图和后续补边都可能改变。

19.1.2 弦化与完美消除序

无向图的下一类转换服务于删点与定向。若删去一个节点以后，它尚未删除的邻居并未两两相连，后续计算通常会产生同时依赖这些邻居的新函数；图上需要用新增边记录这种联系。

定义 19.5 弦图与弦化 设 $\mathcal{U} = (V, E)$ 为有限无向图。一条连接某个环上两个非相邻节点的边称为该环的**弦** (chord)。若 $\mathcal{U}$ 中每个长度至少为四的环都有弦，则称 $\mathcal{U}$ 为**弦图** (chordal graph)；等价地， $\mathcal{U}$ 不含长度至少为四的诱导环。

若通过加入边集 F 得到弦图 $\tilde{\mathcal{U}} = (V, E \cup F)$ ，则 F 中的边称为**填充边** (fill-in edge)，从 $\mathcal{U}$ 得到 $\tilde{\mathcal{U}}$ 的过程称为**弦化** (chordal completion，也称 triangulation)。

定义 19.6 完美消除序与完美有向图 设 $\mathcal{U} = (V, E)$ 为有限无向图，且 $d = |V|$ 。将 V 中的节点排为 $v_1, \dots, v_d$ ，并记

$$N_k^+ = \{v_\ell : \ell > k, \{v_k, v_\ell\} \in E\}.$$

若每个 N_k^+ 中的任意两个不同节点都相邻，则该排列称为 $\mathcal{U}$ 的**完美消除序** (perfect elimination ordering, PEO)；空集与单元素集自动满足成团条件。设 $\mathcal{D} = (W, F)$ 为有限有向无环图。若 $\mathcal{D}$ 中每个节点的父节点两两相邻，则称 $\mathcal{D}$ 为**完美有向图** (perfect directed acyclic graph)；等价地，它不含形如 $i \rightarrow k \leftarrow j$ 且 i, j 不相邻的碰撞结构。

有限无向图是弦图，当且仅当它存在完美消除序。图 19.2 中的四环没有弦；加入 $1-3$ 以后， $(4, 2, 1, 3)$ 成为完美消除序。读者应观察每一步待删除节点的剩余邻居：删 4 和删 2 时，邻居 1, 3 都已由填充边连接；再删 1 与 3 时，成团条件自动成立。最后把每条边从消除序中较晚的节点指向较早的节点，也就是沿删点次序的反方向定向，便得到无环且父集成团的完美有向图。




图 19.2 从无弦四环到完美有向图。先加入虚线填充边 $1-3$ 完成弦化，再按完美消除序 $(4, 2, 1, 3)$ 逐步删点；红色双圈标出当前消去节点，已消去节点保留为灰色虚线轮廓，便于跨快照对照。序列上方给出通用规则：elim(X_k) 时补齐其未消去邻居为团。最终从序中较晚节点指向较早节点；实线箭头来自原四环，虚线箭头来自填充边。

19.2 有向图与无向图的条件独立性关系

结构转换本身只说明怎样改图，还没有说明改图前后的概率语义是否相同。一张图通常只给出分布必须满足的一部分独立性，而不声称相连的变量一定依赖。要比较不同图，先把“图能读出什么”与“分布实际上满足什么”分别记下来，才能准确判断转换保留了哪些信息。

19.2.1 独立性映射

记 $\mathcal{I}(p)$ 为分布 p 实际满足的条件独立关系集合：

$$\mathcal{I}(p) = \{(A, B \mid S) : \mathbf{X}_A \perp \mathbf{X}_B \mid \mathbf{X}_S\}, \quad (19.1)$$

其中 $A, B, S \subseteq V$ 两两不交, A, B 非空, S 可以为空。记 $\mathcal{I}(\mathcal{G})$ 为图的分离规则蕴含的同类集合: 有向图使用 d-分离, 无向图使用无向分离。这里比较的是对条件变量成立的独立性, 不只是某个特定取值下偶然成立的等式。

独立性映射 (independency map, I-map) 表示图没有作出错误的独立性声明, 但允许漏掉真实独立性; **依赖性映射** (dependency map, D-map) 要求分布的真实独立性都能在图上找到, 但允许图多声明一些。两种要求同时成立, 才是**完美映射** (perfect map), 即图与分布在独立性上完全一致。

定义 19.7 三类独立性映射 对同一组随机变量的分布 p 与图 $\mathcal{G}$, 有

$$\begin{aligned}\mathcal{G} \text{ 是 } p \text{ 的 I-map} &\iff \mathcal{I}(\mathcal{G}) \subseteq \mathcal{I}(p), \\ \mathcal{G} \text{ 是 } p \text{ 的 D-map} &\iff \mathcal{I}(p) \subseteq \mathcal{I}(\mathcal{G}), \\ \mathcal{G} \text{ 是 } p \text{ 的完美映射} &\iff \mathcal{I}(\mathcal{G}) = \mathcal{I}(p).\end{aligned}\tag{19.2}$$

定义 17.9 中的忠实性, 正是要求有向图 $\mathcal{G}$ 成为 p 的完美映射。可靠性保证 $\mathcal{G}$ 是 p 的 I-map, 忠实性再补上 D-map 方向。

集合方向可以用两个极端检验。完全无向图不分离任何两个非空节点集合, 因而它对任意 p 都是 I-map: 它没有独立性声明, 也就不会声明错。反过来, 无边图声明所有互不相交的变量组在给定其余不交变量后仍独立, 因此它对任意 p 都是 D-map, 但通常不是 I-map。D-map 中的“依赖”来自集合包含关系的逆否表述: 对于给定的 A, B, S , 若图没有用 S 分离 A, B , 则 D-map 条件保证 $\mathbf{X}_A$ 与 $\mathbf{X}_B$ 在 p 中给定 $\mathbf{X}_S$ 也不独立。这一要求涉及全部查询, 不限于相邻节点。实际建模通常先要求 I-map, 因为错误地删除真实依赖, 会把 p 排除在模型之外¹。

即使 I-map 中的每条边都不能再删, 它也不一定是完美映射。**最小 I-map** (minimal I-map) 只要求删去任何一条边后, 图不再是 p 的 I-map; 这里的“最小”是相对于删边操作而言, 不要求在所有候选图中边数最少, 也不要求唯一。以两个二元变量为例, 令

$$p(0, 0) = p(1, 1) = 0.4, \quad p(0, 1) = p(1, 0) = 0.1.$$

由于 $p(X_1 = 0) = p(X_2 = 0) = 0.5$ 而 $p(0, 0) \neq 0.25$, 两变量不独立。 $X_1 \rightarrow X_2$ 和 $X_1 \leftarrow X_2$ 都是最小 I-map: 保留边时没有错误声明, 删边就会错误地要求独立。这个例子也说明, 最小性不足以确定方向。一般情况下, 某张最小 I-map 仍可能漏掉无法由其图形同时表达的其他独立性。

同样的记号可以用于两张图的比较: 若 $\mathcal{I}(\mathcal{G}_2) \subseteq \mathcal{I}(\mathcal{G}_1)$, 则 $\mathcal{G}_2$ 是 $\mathcal{G}_1$ 的 I-map。此时 $\mathcal{G}_2$ 施加的独立性约束较少; 只考虑 Markov 约束而不另加参数限制时, 它容纳的分布族较大。后面出现的道德化和填充边, 主要沿着这个方向改变图。

¹ D. Koller, N. Friedman, *Probabilistic Graphical Models: Principles and Techniques*, MIT Press, 2009

19.2.2 d-分离的无向判据

祖先图已经排除不可能参与当前查询的节点，道德图则把碰撞结构的影响转成普通无向边。于是，d-分离可以改写为祖先道德图上的无向分离。

定理 19.8 祖先道德化判据 设 $\mathcal{G} = (V, E)$ 为有限有向无环图， $A, B, S \subseteq V$ 两两不交且 A, B 非空，并令

$$U = \text{an}^+(A \cup B \cup S).$$

则 A 与 B 在 $\mathcal{G}$ 中被 S d-分离，当且仅当它们在 $\text{mor}(\mathcal{G}[U])$ 中被 S 无向分离。

定理 19.8 的证明. 先设原有向图有一条给定 S 时连接 A 与 B 的活跃路径。路径上的碰撞节点属于 $\text{an}^+(S)$ 。从任一非碰撞内部节点出发，至少能沿路径的一侧顺着箭头前进，直到到达端点或碰撞节点，所以该节点也是 $A \cup B \cup S$ 中某个节点的祖先。整条路径因而位于 $\mathcal{G}[U]$ 中。凡遇到属于 S 的碰撞片段 $u \rightarrow c \leftarrow v$ ，就用道德图中的边 $u - v$ 替代；非碰撞节点本来就不在 S 中。替换得到一条避开 S 的无向路线，删去重复片段便得到无向路径。

反过来，设 $\text{mor}(\mathcal{G}[U])$ 中有一条避开 S 、连接 A 与 B 的路径。保留来自原有向图骨架的边，把每条道德化新增边 $u - v$ 展开为 $u \rightarrow c \leftarrow v$ ，其中 $c \in U$ 是使该边加入的共同子节点。展开后可能重复经过节点，暂称为路线。原无向路径上的节点都不在 S 中，新插入的节点在插入位置都是碰撞节点，但其中某些碰撞节点可能只属于 A 或 B 的祖先，而不属于 $\text{an}^+(S)$ 。

对这种尚未打开的碰撞节点 c ，若 c 本身属于 A 或 B ，就在该位置截去路线对应的前缀或后缀，使 c 成为端点。否则，由 $c \in U$ 可知，存在从 c 到 $A \cup B$ 中某个节点的有向路径；这条有向路径不经过 S ，否则 c 已经属于 $\text{an}^+(S)$ 。若终点在 A 中，就用该有向路径的反向行走替换原路线从 A 端点到 c 的部分；若终点在 B 中，则替换 c 到 B 端点的部分。新的接合处 c 有一条向外的边，因而不再是碰撞节点，替换段内部也没有碰撞节点。每次操作至少减少一个未打开的碰撞位置，且不会增加新的未打开位置，有限次后得到活跃路线。

还需从可能重复节点的活跃路线取得路径。取一条长度最短的活跃路线。若内部节点 v 出现两次，删除两次出现之间的片段；除接合处 v 外，所有节点的角色不变。若 $v \in S$ ，两个出现位置原本都必须是碰撞位置，接合后仍是碰撞；若 $v \notin S$ ，唯一可能出错的是接合后形成一个不属于 $\text{an}^+(S)$ 的碰撞节点。此时被删片段从 v 沿出边开始，又逆着 v 的另一条出边返回，沿该片段必然遇到一个作为 v 后代的碰撞节点。原路线活跃使这个碰撞节点属于 $\text{an}^+(S)$ ，进而推出 $v \in \text{an}^+(S)$ ，与可能出错的假设矛盾。端点重复

时直接截去相应前缀或后缀即可。因此最短活跃路线没有重复节点，是所需的活跃路径。 ■

这个判据是纯图论结论，不依赖某张条件概率表，也不要求分布严格为正。应用时应依次确定相关祖先、取诱导子图、道德化，再删除条件节点 S 检查连通性。不能先删除条件节点再道德化，因为一个被观察的碰撞点虽将从无向查询图中删除，它的父节点之间却必须留下新增边。祖先道德图与全局 Markov 性质的系统论述可参见 Lauritzen 的教材²。

² S. L. Lauritzen, *Graphical Models*, Clarendon Press, 1996

图 19.1 展示查询 $F \perp S \mid A$ 的转换。删除条件节点 A 以后，补出的 $H-S$ 边仍使 $F-H-S$ 连通，所以图不能推出该条件独立。若改为检验 $F \perp S$ ，相关祖先只有 $\{F, S\}$ ： H, A, D 都不是这两个根节点的祖先，查询祖先图没有边，因而得到独立性。这一对比说明，图中原始箭头虽然固定，查询祖先图与道德化时需要补出的边却随 $(A, B \mid S)$ 改变；图上未分离只是否定结构保证，并不声称每组参数都一定产生依赖。

保留祖先并不是保留端点的另一种说法。在辅助例子 $X_1 \leftarrow X_0 \rightarrow X_2$ 中，查询 $X_1 \perp X_2$ 时， X_0 不在端点集合中，却是必须保留的共同祖先；只保留 $\{1, 2\}$ 会错误地把两个节点分开。条件节点的祖先也不可漏掉：在 $X_1 \rightarrow X_3 \leftarrow X_2, X_3 \rightarrow X_4$ 中，给定 X_4 会激活 X_3 处的碰撞结构。查询 $\{1\}$ 与 $\{2\}$ 给定 $\{4\}$ 时必须保留 X_3 ，道德化才会生成 $1-2$ 边。

这里还要区分为查询构造的祖先道德图与整个有向图的道德图。若把报警模型整体道德化，即使查询没有给定 A ， $F-H-S$ 也始终存在，原来的 $F \perp S$ 就无法从这张无向图读出。整体道德化并非错误操作，它服务于联合因子分解的转换；只是它通常给出较弱的独立性描述。准确的图关系是

$$\mathcal{I}(\text{mor}(\mathcal{G})) \subseteq \mathcal{I}(\mathcal{G}), \quad (19.3)$$

而不是相等。整体道德图中若已经被 S 分离，在更小的祖先道德图中仍被分离，所以它可以证明一部分 d-分离；整体图中连通则不能据此否定原有向图中的 d-分离。

19.2.3 有向图独立性结论的证明

祖先道德化不仅给出检测方法，也补上了第 17 章各项结论之间的证明链。下面集中给出这些证明：先处理局部归一化和分解关系，再用祖先道德图证明全局 Markov 性质，最后处理 Markov 毯与完备性；每一步只调用此前已经定义或证明的对象。

引理 17.11 的证明。取有向图一个拓扑序中的最后一个节点。它没有子节点，故在全部乘积中只有自己的因子依赖它；对该节点关于 μ_i 积分后，这

个因子变成 1。按逆拓扑序重复消去节点，由非负性和 Tonelli 定理可以交换积分次序，最终得到总积分 1。有限离散情形中，这些积分就是求和。

对祖先边缘化结论，只消去 $V \setminus W$ 。由于 W 包含其中每个节点的全部祖先， $V \setminus W$ 中的节点不可能有位于 W 的子节点。按照逆拓扑序消去补集时，当前节点在补集中的子节点都已经消去，因此当前剩余乘积中仍只有自己的因子依赖它。依次积分后留下且仅留下式 (17.7) 中的因子。 ■

定理 17.13 的证明. 按有序 Markov 假设所固定的拓扑序应用概率链式法则：

$$p(x_1, \dots, x_d) = \prod_{i=1}^d p(x_i \mid x_1, \dots, x_{i-1}).$$

由式 (17.1)，每个条件项都可以删除非父前驱变量，即

$$p(x_i \mid \mathbf{x}_{\text{pre}(i)}) = p(x_i \mid \mathbf{x}_{\text{pa}(i)}).$$

将这些等式代回链式法则，便得到式 (17.6)。条件等式在对应前驱配置的分布下几乎处处成立。离散情形若某个前缀具有零概率，后续条件表可以任意归一化补全，因为该前缀对应的联合概率仍为零；也可以按前缀长度归纳验证两个乘积给出的前缀分布始终相同。连续情形使用条件密度的版本，得到几乎处处相同的联合密度。整个证明始终使用同一个拓扑序。 ■

定理 17.12 的证明. 固定节点 i ，令 $N = \text{nd}(i)$ 。 N 中的节点既不可能以 i 为祖先，也不可能以 i 的后代为祖先； i 的祖先又都属于 N 。因此， N 与 $N \cup \{i\}$ 都包含其中每个节点的全部祖先。由引理 17.11 的祖先边缘化结论，

$$\begin{aligned} p(x_i, \mathbf{x}_N) &= q_i(x_i \mid \mathbf{x}_{\text{pa}(i)}) \prod_{j \in N} q_j(x_j \mid \mathbf{x}_{\text{pa}(j)}) \\ &= q_i(x_i \mid \mathbf{x}_{\text{pa}(i)}) p(\mathbf{x}_N). \end{aligned}$$

于是 $p(x_i \mid \mathbf{x}_N) = q_i(x_i \mid \mathbf{x}_{\text{pa}(i)})$ ，等式按条件分布的定义域理解。再对 $N \setminus \text{pa}(i)$ 边缘化，可知 q_i 也是 $p(x_i \mid \mathbf{x}_{\text{pa}(i)})$ 的一个版本；条件分布不依赖非父节点的非后代，局部 Markov 性质成立。

在任一固定拓扑序中， $\text{pre}(i) \subseteq N$ 。从局部独立陈述中边缘化其余非后代，便得到该顺序下的有序 Markov 性质。这里是在局部性质成立以后使用集合包含关系，没有预先假设分布满足另一个顺序的有序性质。 ■

接下来证明全局结论。以下用求和写离散情形；对于具有联合密度的连续变量，将求和换成相对于相应基准测度的积分，并用 Tonelli 定理交换非负函数的积分次序。

定理 17.6 的证明. 设 $p \in \mathcal{M}(\mathcal{G})$ 且 $A \perp_{\mathcal{G}} B \mid S$ 。由定理 17.13， p 按 $\mathcal{G}$ 分解，

记节点 i 的局部因子为 $q_i(x_i | \mathbf{x}_{\text{pa}(i)})$ 。令 $R = \text{an}^+(A \cup B \cup S)$, 对 $V \setminus R$ 边缘化后, 由引理 17.11,

$$p(\mathbf{x}_R) = \prod_{i \in R} q_i(x_i | \mathbf{x}_{\text{pa}(i)}).$$

每个因子的作用域 $\{i\} \cup \text{pa}(i)$ 在 $\text{mor}(\mathcal{G}[R])$ 中两两相连。删去 S 后, 一个因子的非条件节点不可能分属两个连通分量, 否则这些节点之间的无向边会连接相应分量。

令 C 为 $\text{mor}(\mathcal{G}[R]) \setminus S$ 中所有与 A 相交的连通分量之并, 令 $D = R \setminus (C \cup S)$ 。由定理 19.8, $B \subseteq D$ 。把非条件作用域落在 C 中的因子相乘得到 $g(\mathbf{x}_C, \mathbf{x}_S)$, 落在 D 中的因子相乘得到 $h(\mathbf{x}_D, \mathbf{x}_S)$, 只涉及 S 的因子相乘得到 $k(\mathbf{x}_S)$, 于是

$$p(\mathbf{x}_R) = g(\mathbf{x}_C, \mathbf{x}_S)h(\mathbf{x}_D, \mathbf{x}_S)k(\mathbf{x}_S).$$

分别对 $C \setminus A$ 和 $D \setminus B$ 边缘化, 记所得函数为 g_A, h_B , 便有

$$p(\mathbf{x}_A, \mathbf{x}_B, \mathbf{x}_S) = g_A(\mathbf{x}_A, \mathbf{x}_S)h_B(\mathbf{x}_B, \mathbf{x}_S)k(\mathbf{x}_S).$$

对具有正且有限边缘质量或密度的 $\mathbf{x}_S$, 令 $G(\mathbf{x}_S) = \sum_{\mathbf{x}_A} g_A(\mathbf{x}_A, \mathbf{x}_S)$ 、 $H(\mathbf{x}_S) = \sum_{\mathbf{x}_B} h_B(\mathbf{x}_B, \mathbf{x}_S)$ 。对条件联合分布归一化后,

$$\begin{aligned} p(\mathbf{x}_A, \mathbf{x}_B | \mathbf{x}_S) &= \frac{g_A(\mathbf{x}_A, \mathbf{x}_S)}{G(\mathbf{x}_S)} \frac{h_B(\mathbf{x}_B, \mathbf{x}_S)}{H(\mathbf{x}_S)} \\ &= p(\mathbf{x}_A | \mathbf{x}_S)p(\mathbf{x}_B | \mathbf{x}_S). \end{aligned}$$

零质量条件值无需作比值, 连续密度中的异常取值按几乎处处约定处理。由此得到所需条件独立性, 且证明不要求联合分布严格为正。 ■

定理 17.3 的证明. 令 $O = V \setminus (\{i\} \cup \text{mb}(i))$ 。若 $O = \emptyset$, 则定理所述的条件独立按定义平凡成立。以下设 $O \neq \emptyset$, 并考虑任意一条从 i 到 O 中节点的路径。路径的第一个相邻节点不可能已经属于 O , 因为 i 的每个父节点和子节点都在 $\text{mb}(i)$ 中。

若路径先经过父节点 $j \rightarrow i$, 则 j 在路径上是非碰撞节点, 而且 $j \in \text{mb}(i)$, 所以给定 Markov 毯会在 j 处阻断路径。若路径先沿 $i \rightarrow j$ 经过子节点 j , 随后沿 $j \rightarrow k$ 离开, 则 j 是已给定的非碰撞节点, 路径同样被阻断。剩下的情形是路径以 $i \rightarrow j \leftarrow k$ 开头; 此时 j 虽是已给定的碰撞节点, 但 k 是 j 的另一个父节点, 因而也属于 $\text{mb}(i)$ 。节点 k 不是路径终点, 并且边 $k \rightarrow j$ 在 k 处给出箭尾, 所以 k 是已给定的非碰撞节点, 路径在此被阻断。

所有从 i 到 O 的路径都被 $\text{mb}(i)$ 阻断, 即 $i \perp_{\mathcal{G}} O | \text{mb}(i)$ 。定理 17.6 再把这个图论分离转成定理所述的条件独立。

同一屏蔽关系也可以从局部因子直接读出。由定理 17.13, 给定其余变

量后，联合乘积中只有节点 i 及其子节点的因子含 x_i ，所以

$$p(x_i | \mathbf{x}_{V \setminus \{i\}}) \propto q_i(x_i | \mathbf{x}_{\text{pa}(i)}) \times \prod_{j \in \text{ch}(i)} q_j(x_j | \mathbf{x}_{\text{pa}(j)}). \quad (19.4)$$

右侧除 x_i 外只涉及 $\text{mb}(i)$ 中的变量，对 x_i 归一化不会引入额外变量。比例式只在条件分布有定义的配置上使用；零概率条件配置仍按第 17 章约定选取条件分布版本。 ■

现在可以闭合第 17 章的四种表述。有序 Markov 性质由定理 17.13 推出因子分解；因子分解由定理 17.6 推出全局 Markov 性质；全局性质由引理 17.5 推出局部性质；局部性质又由定理 17.12 中的边缘化论证推出任一拓扑序下的有序性质。因此式 (17.10) 成立，并且整个等价链不要求联合分布严格为正。

完备性处理相反方向：若图中仍有活跃路径，需要证明至少能选择一组相容参数，使路径两端在给定条件集后确实不独立。先看一个可以逐项复算的连续构造。考虑图 $X \rightarrow Z \leftarrow Y$ 以及 $Z \rightarrow D$ ，令

$$\begin{aligned} X &= \varepsilon_X, & Y &= \varepsilon_Y, \\ Z &= X + Y + \varepsilon_Z, & D &= Z + \varepsilon_D, \end{aligned}$$

其中四个噪声相互独立，均服从 $\mathcal{N}(0, 1)$ 。该分布按有向图分解，且 X, Y 边缘独立。由高斯条件协方差公式，


$$\begin{aligned} \text{Cov}(X, Y | Z) &= 0 - \frac{1 \cdot 1}{3} = -\frac{1}{3}, \\ \text{Cov}(X, Y | D) &= 0 - \frac{1 \cdot 1}{4} = -\frac{1}{4}. \end{aligned}$$

条件协方差公式来自将每个变量对观测作线性回归后，计算两个回归残差的协方差；对联合高斯变量，残差与观测独立，故它正是条件协方差。两个非零结果分别验证了观测碰撞节点、观测其后代时的依赖，但这个四节点构造还不能代替任意有向图上的证明。

一般图中的活跃路径可能包含多个碰撞节点，它们通向条件节点的有向路径还可能相交。直接声称“给活跃路径每条边一个非零系数就必然不独立”并不成立。图 19.3 给出反例：令

$$X = \varepsilon_X, \quad Z = X + \varepsilon_Z, \quad Y = -X + Z + \varepsilon_Y,$$

各噪声仍相互独立且服从 $\mathcal{N}(0, 1)$ 。图中三条边的系数都非零，但代入后 $Y = \varepsilon_Z + \varepsilon_Y$ ，从而 $X \perp Y$ 。直接路径与间接路径的作用恰好抵消。改变 $X \rightarrow Y$ 的系数为 $-1 + \delta$ ，则 $\text{Cov}(X, Y) = \delta$ ；只要 $\delta \neq 0$ ，这个额外独立性便消失。



$$Y = -X + (X + \varepsilon_Z) + \varepsilon_Y = \varepsilon_Z + \varepsilon_Y$$

图 19.3 参数抵消造成的额外独立性。 $X \rightarrow Y$ 的直接系数为 -1 ，经 Z 的两条系数均为 1 ；两条路径都没有被空集阻断，但这个特定高斯分布中 X 与 Y 独立。

一般有向图上的完备性依赖下面的关键引理。它的作用是排除“所有相容参数都因路径抵消而满足额外独立性”的可能；后面的代数论证只负责从非零多项式得到所需参数，不会把这一关键图论事实重新证明。离散结论及其路径构造见 Meek 的强完备性证明，高斯结论可由线性高斯有向图的标准多项式完备性论证得到³。

引理 19.9 条件独立约束的非平凡性 设 $\mathcal{G} = (V, E)$ 为有限有向无环图， $u, v \in V$ 为不同节点， $S \subseteq V \setminus \{u, v\}$ ，且 u, v 在 $\mathcal{G}$ 中给定 S 时 d-连接，则以下两项成立。

1. 对 $i \in V$ ，在线性高斯系统

$$X_i = \sum_{j \in \text{pa}(i)} b_{i,j} X_j + \varepsilon_i, \quad \varepsilon_1, \dots, \varepsilon_d \stackrel{\text{ind}}{\sim} \mathcal{N}(0, 1)$$

中，记边系数为 θ 、协方差矩阵为 $\Sigma(\theta)$ ，则

$$f_{u,v,S}(\theta) = \det \Sigma_{(u,S),(v,S)}(\theta)$$

是非零多项式。行指标按 u 及 S 排列，列指标按 v 及同一顺序的 S 排列； $S = \emptyset$ 时，该式为 $\Sigma_{u,v}$ 。

2. 固定每个节点至少含两个状态的有限状态空间，并用各行前 $r_i - 1$ 个概率参数化局部条件表。将联合概率与边缘概率写成这些参数的多项式后，在所有状态配置对应的条件独立多项式

$$p(x_u, x_v, \mathbf{x}_S) p(\mathbf{x}_S) - p(x_u, \mathbf{x}_S) p(x_v, \mathbf{x}_S)$$

中，至少有一个不是零多项式。

³ C. Meek, *Strong Completeness and Faithfulness in Bayesian Networks* In Proceedings of the Eleventh Conference on Uncertainty in Artificial Intelligence, 1995, pp. 411–418; D. Koller, N. Friedman, *Probabilistic Graphical Models: Principles and Techniques*, MIT Press, 2009

这项引理在此作为有来源的外部结果使用，不把路径缩减的说明冒充

完整证明。其证明需要从活跃路径及碰撞节点通向 S 的有向路径中提取仍保留连接的子图，并控制这些路径交会时可能发生的代数抵消。高斯模型允许任意正噪声方差；单位方差子类已经足以证明存在性，而逐坐标可逆缩放也不改变条件独立性。

定理 17.8 的线性高斯部分. 若集合 A, B 未被 S d -分离, 就有某个 $u \in A, v \in B$ 之间存在活跃路径。在引理 19.9 的线性系统中, 令 B 为严格下三角系数矩阵, 其非边元素为零。因为 $B^d = 0$,

$$L = (I - B)^{-1} = I + B + \cdots + B^{d-1},$$

$$\Sigma(\theta) = LL^\top.$$

因此协方差的每个元素都是边系数的多项式, 且对所有实边系数, Σ 都正定。分块行列式恒等式给出

$$f_{u,v,S}(\theta) = \det(\Sigma_{S,S})(\Sigma_{u,v} - \Sigma_{u,S}\Sigma_{S,S}^{-1}\Sigma_{S,v}).$$

括号内是 $\text{Cov}(X_u, X_v | \mathbf{X}_S)$; S 为空时约定空矩阵行列式为 1, 不执行矩阵求逆。高斯条件分布中, 这个协方差为零当且仅当两个标量条件独立。引理说明 $f_{u,v,S}$ 不是零多项式, 因而存在系数使它不为零。

还可以给出一个不追求效率的确定构造: 按有理数分子绝对值和正分母的界依次枚举所有有理边系数向量, 逐一用有理数运算计算上述行列式, 找到非零值就停止。非零多项式在某个实参数点附近保持非零, 而有理向量在实空间中稠密, 所以枚举必会停止。输出系数与单位独立高斯噪声定义一个属于 $\mathcal{M}_{LG}(\mathcal{G})$ 的分布, 且 $X_u \not\perp X_v | \mathbf{X}_S$ 。若整个向量 $\mathbf{X}_A, \mathbf{X}_B$ 条件独立, 其任意坐标对应也条件独立, 与这个结果矛盾; 所求集合查询的反例由此构造出来。 ■

有限离散变量不能用高斯构造代替。将每张局部条件概率表中除最后一个状态以外的概率作为自由参数, 最后一个概率由行和为 1 确定; 严格正条件表构成这个有限维参数空间中的一个非空开集。联合概率和边缘概率都是这些参数的多项式, 而给定 S 时 X_u 与 X_v 条件独立, 等价于对所有状态配置同时满足

$$p(x_u, x_v, \mathbf{x}_S)p(\mathbf{x}_S) - p(x_u, \mathbf{x}_S)p(x_v, \mathbf{x}_S) = 0.$$

定理 17.8 的有限离散部分. 仍取活跃路径连接的 $u \in A, v \in B$ 。引理 19.9 的第二项表明, 上述有限组多项式中至少有一个不是零多项式。非零多项式不可能在参数空间的非空开集上处处为零, 因此存在一组严格为正的局部条件表, 使至少一个条件独立等式失败。由这些条件表得到的联合分布属

于 $\mathcal{M}_{\text{disc}}^+(\mathcal{G})$, 且 $X_u \perp\!\!\!\perp X_v \mid \mathbf{X}_S$ 。若 $\mathbf{X}_A \perp\!\!\!\perp \mathbf{X}_B \mid \mathbf{X}_S$ 成立, 则任意坐标对也应条件独立, 产生矛盾。因此 $\mathbf{X}_A \not\perp\!\!\!\perp \mathbf{X}_B \mid \mathbf{X}_S$ 。■

同一多项式论证还解释了忠实分布为何存在。在固定有限图上, 需要检查的节点对与条件集合只有有限多组; 每个未分离查询出现额外独立性, 都要求相应的一个或多个非零多项式同时取零。非零多项式的零点集具有 Lebesgue 测度零, 有限个零点集之并仍不能覆盖具有非空内部的参数空间。因此, 在上述不受额外限制的离散或线性高斯参数族中存在忠实分布, 而且不忠实参数只占零测集。这个结论不保证真实系统必然忠实, 也不排除参数接近抵消集合时, 有限样本很难识别微弱依赖。

19.2.4 两类独立性表示的差异

祖先道德化借助“每个查询一张图”复现 d-分离, 并没有给出一张同时回答全部查询的完美无向图。这个区别在最小的碰撞结构 $X_1 \rightarrow X_3 \leftarrow X_2$ 中已经出现: 有向图声明 $X_1 \perp\!\!\!\perp X_2$, 却不声明 $X_1 \perp\!\!\!\perp X_2 \mid X_3$ 。在任何无向图中, 若 1 与 2 已被空集分离, 它们原本就没有路径; 再删除节点 3 不可能创造路径。因而同一节点集合上不存在具有完全相同分离关系的无向图。这里否定的是图独立性集合的完全相同, 不是某个特殊分布碰巧可由两类图共同表示。

无向图也有有向图不能完美表达的结构。考虑图 19.2 左侧的四环 1-2-3-4-1, 其中没有 1-3 或 2-4 边。它同时声明

$$X_1 \perp\!\!\!\perp X_3 \mid (X_2, X_4), \quad X_2 \perp\!\!\!\perp X_4 \mid (X_1, X_3). \quad (19.5)$$

若要用同一骨架定向, 又不形成有向环, 就必须使某个环上节点同时接收两条邻边。例如令 $2 \rightarrow 1 \leftarrow 4$, 由于 2 与 4 不相邻, 便出现了未被邻接边遮蔽的碰撞结构。给定 $\{1, 3\}$ 反而会打开 $2 \rightarrow 1 \leftarrow 4$, 与式 (19.5) 中的第二个独立性冲突。

为什么必须出现这种碰撞? 取任意拓扑序, 选择四环中排在最晚的节点, 其两个环上邻居都排在它之前, 邻边便都指向它。更换拓扑序只能移动碰撞的位置, 不能消除这个问题。具有相同独立性的有向图也不能通过改变骨架来避开反例。具体地说, 对有向图中任意两个不相邻节点 i, j , 无环性保证至少可以选择其中一个节点, 例如 i , 使 j 不是 i 的后代。由于 j 也不是 i 的父节点, 局部 Markov 性质给出某个分离关系, 例如 $X_i \perp\!\!\!\perp X_j \mid \mathbf{X}_{\text{pa}(i)}$ 。无向图中的不相邻节点则可由其余所有节点分离。反过来, 无论在有向图还是无向图中, 相邻节点之间长度为一的路径都不可能不含端点的条件集阻断。因此, 一张图的全部分离关系能够确定哪些节点相邻; 两张图若有相同的独立性集合, 骨架就必须相同。

碰撞结构与无弦四环分别给出一种无法跨图类型完美表达的独立性模

式, 说明两类表示的一般表达能力互不包含。不过, 这些反例不意味着任何有向图和无向图都无法对应; 第 19.1.2 节定义的弦图与完美有向图恰好刻画了可以完美转换的边界。

19.2.5 完美表示的条件

有限无向图是弦图, 当且仅当它存在完美消除序。下面借助这一标准图论结果, 分别陈述无向图何时完美有向表示、有向图何时完美无向表示; 弦图与消除序等价性的图论证明可参见分解图的相关论述⁴。

⁴S. L. Lauritzen, *Graphical Models*, Clarendon Press, 1996

定理 19.10 无向图的完美有向图表示 设 $\mathcal{U} = (V, E_{\mathcal{U}})$ 为有限无向图。存在以同一有限节点集合 V 为节点集的有向无环图 $\mathcal{D} = (V, E_{\mathcal{D}})$, 使按无向分离定义的 $\mathcal{I}(\mathcal{U})$ 与按 d-分离定义的 $\mathcal{I}(\mathcal{D})$ 满足

$$\mathcal{I}(\mathcal{D}) = \mathcal{I}(\mathcal{U}),$$

当且仅当 $\mathcal{U}$ 是弦图。若 $v_1, \dots, v_d$ 是 $\mathcal{U}$ 的完美消除序, 将每条边从序中较晚的节点指向较早的节点, 便得到一个满足上述等式的完美有向图 $\mathcal{D}$ 。

证明. 按上述规则定向时, 沿箭头移动会使序号严格减小, 因此 $\mathcal{D}$ 没有有向环。 v_k 的父集恰好是 N_k^+ , 由完美消除序的定义可知其中的节点两两相邻, 空父集也满足要求。

为证明独立性集合相同, 先设 $\mathcal{U}$ 中存在一条避开 S 、连接 A 与 B 的路径, 并选取最短的一条。若它在 $\mathcal{D}$ 中有碰撞点, 则该点两侧节点都是其父节点, 必然有边直接相连。用这条边可以缩短路径, 产生矛盾。因此这条最短路径没有碰撞点, 又没有经过 S , 故在 $\mathcal{D}$ 中活跃。反过来, 若 $\mathcal{D}$ 中存在活跃路径, 则其中属于 S 的节点只能是碰撞点。利用这些碰撞点父节点间已有的边逐一绕过它们, 就得到一条避开 S 的无向行走; 去掉重复片段即可得到 $\mathcal{U}$ 中的无向路径。这证明两种分离判断对每个 $(A, B \mid S)$ 都等价。

为证明必要性, 假设存在满足独立性集合相等的有限有向无环图 $\mathcal{D}$ 。由前述邻接判据, $\text{skel}(\mathcal{D}) = \mathcal{U}$ 。 $\mathcal{D}$ 不能含有未被遮蔽的碰撞 $i \rightarrow k \leftarrow j$: 不相邻的 i, j 中至少有一个不是另一个的后代, 取相应节点的父集便得到一个不含共同子节点 k 的 d-分离集; 无向路径 $i - k - j$ 却不会被这个集合阻断, 与独立性集合相等矛盾。若 $\mathcal{U}$ 含有长度至少为四的诱导环, 取该环中在 $\mathcal{D}$ 的拓扑序里最晚的节点, 其两个环上邻居都会指向它, 而且两邻居在诱导环中不相邻, 从而形成未被遮蔽的碰撞。故 $\mathcal{U}$ 必须是弦图。 ■

定理 19.11 有向图的完美无向图表示 设 $\mathcal{D} = (V, E_{\mathcal{D}})$ 为有限有向无环图。存在以同一有限节点集合 V 为节点集的有限无向图 $\mathcal{U} = (V, E_{\mathcal{U}})$, 使按 d-分离定义的 $\mathcal{I}(\mathcal{D})$ 与按无向分离定义的 $\mathcal{I}(\mathcal{U})$ 满足

$$\mathcal{I}(\mathcal{U}) = \mathcal{I}(\mathcal{D}),$$

当且仅当 $\mathcal{D}$ 是完美有向图。条件成立时, $\text{skel}(\mathcal{D})$ 是弦图, 并且可以取 $\mathcal{U} = \text{skel}(\mathcal{D})$ 。

证明. 先设 $\mathcal{D}$ 是完美有向图, 并取它的任一拓扑序 $t_1, \dots, t_d$ 。逆序 $t_d, \dots, t_1$ 是 $\text{skel}(\mathcal{D})$ 的完美消除序: 删除 t_i 时尚未删除的邻居恰好是 t_i 的父节点, 而这些父节点按完美有向图的定义已经成团。因此 $\text{skel}(\mathcal{D})$ 是弦图; 沿该完美消除序从较晚节点向较早节点定向, 恰好恢复原图 $\mathcal{D}$ 。由定理 19.10,

$$\mathcal{I}(\text{skel}(\mathcal{D})) = \mathcal{I}(\mathcal{D}),$$

所以取 $\mathcal{U} = \text{skel}(\mathcal{D})$ 即可。

反过来, 设存在同一节点集合上的有限无向图 $\mathcal{U}$ 满足 $\mathcal{I}(\mathcal{U}) = \mathcal{I}(\mathcal{D})$ 。邻接判据给出 $\mathcal{U} = \text{skel}(\mathcal{D})$ 。若 $\mathcal{D}$ 含有未被遮蔽的碰撞 $i \rightarrow k \leftarrow j$, 则 i, j 不相邻。两者中至少有一个不是另一个的后代, 不妨设 j 不是 i 的后代; 于是 i 与 j 在 $\mathcal{D}$ 中被 $\text{pa}(i)$ d-分离, 而且作为 i 的子节点, $k \notin \text{pa}(i)$ 。无向图 $\mathcal{U}$ 中的路径 $i - k - j$ 仍然避开 $\text{pa}(i)$, 所以同一条件集不能无向分离 i, j , 产生矛盾。因此 $\mathcal{D}$ 不含未被遮蔽的碰撞, 也就是完美有向图。 ■

此处“完美有向图”描述父集成团这一图结构性性质; “ $\mathcal{D}$ 是 p 的完美映射”还涉及具体分布。即使 $\mathcal{D}$ 与 $\mathcal{U}$ 的图独立性完全相同, 某组特殊参数仍可能使 p 多出额外独立性, 不能混淆这两个“完美”。

图 19.2 也展示了不满足条件时怎样放宽结构。对四环加入 $1 - 3$, 得到两个极大团 $\{1, 2, 3\}$ 和 $\{1, 3, 4\}$; 若原图为 $\mathcal{U}$ 、弦化后为 $\tilde{\mathcal{U}}$, 则

$$\mathcal{I}(\tilde{\mathcal{U}}) \subseteq \mathcal{I}(\mathcal{U}).$$

因为填充边只能增加路径, 不会创造新的分离。四环中 $X_2 \perp X_4 \mid (X_1, X_3)$ 仍可读出, 但 $X_1 \perp X_3 \mid (X_2, X_4)$ 不再由新图声明。弦化因此能够为消除和定向建立所需结构, 代价是新图可能不再声明原图的全部独立性。

19.3 有向图与无向图的因子分解关系

图独立性无法无损互换, 并不意味着概率值也必须改变。若只是把同一组函数重新组织, 原分布可以完整保留。这里应固定一个已给定的 p 来研究

代数转换，再单独考察转换后图结构允许的更大模型族。

19.3.1 两类因子分解的差异

有向图模型给出

$$p(\mathbf{x}) = \prod_{i \in V} p(x_i | \mathbf{x}_{\text{pa}(i)}). \quad (19.6)$$

其中每张局部条件表对每种父节点配置都满足 $\sum_{x_i} p(x_i | \mathbf{x}_{\text{pa}(i)}) = 1$ 。这种局部归一化为什么足以保证联合归一化？取一个没有子节点的节点，它只出现在自己的条件因子中，对它求和后这个因子变为 1。删除该节点后仍是有向图，可以重复这一过程，直到所有因子都被消去，得到 $\sum_{\mathbf{x}} p(\mathbf{x}) = 1$ 。没有有向环保证了每步都能找到这样的节点。

Markov 网络则以非负势函数表示

$$p(\mathbf{x}) = \frac{1}{Z} \prod_{C \in \mathcal{C}} \psi_C(\mathbf{x}_C), \quad Z = \sum_{\mathbf{x}} \prod_{C \in \mathcal{C}} \psi_C(\mathbf{x}_C), \quad (19.7)$$

其中 $\mathcal{C}$ 是选定的团作用域集合，未必只包含极大团，并要求 $0 < Z < \infty$ 。势函数的数值是对局部配置的相对权重，不要求对任何一个变量求和为 1。共享变量使不同势函数的归一化互相影响，所以不能把每个势单独除以其元素和，就认为联合函数已归一化。把某个势乘以正的常数会同时缩放 Z ，却不改变 p ，这也表明原始势表通常有冗余参数。

对于连续变量，应将求和改为相对于指定乘积测度的积分，并要求所得函数可测、非负且可归一化；局部密度的归一化也按相应积分理解。由给定非负团因子分解推出无向全局 Markov 性质，不需要额外假设严格正性；反过来，仅凭无向 Markov 独立性保证团分解时，严格正性等条件不能省略。本节后面的条件表重组在有限离散、严格正的分布下推导，避免在零概率条件事件上除以零。

19.3.2 从有向因子分解到无向因子分解

式 (19.6) 中的每个因子作用于 $\{i\} \cup \text{pa}(i)$ 。在有向图的整体道德图中，这个集合恰好被连成团。因此可以直接令

$$\psi_{\{i\} \cup \text{pa}(i)}(x_i, \mathbf{x}_{\text{pa}(i)}) = p(x_i | \mathbf{x}_{\text{pa}(i)}),$$

把所有这些局部因子相乘；作用域重复时，可以保留多个因子，也可以合并。乘积没有改变，原有局部归一化保证这里的 $Z = 1$ 。若希望每个极大团只有一个势，则把每个因子恰好分配给一个包含其作用域的极大团，再在团内相乘；没有分到因子的团取恒为 1 的势。这仍不改变联合函数。这里要求“极大”而非“最大”：不能再扩张的团足以覆盖全部因子，节点数最多的团却未必覆盖其他作用域。

在报警模型中, 该变换为

$$\begin{aligned}
 p(f, h, a, s) &= p(f)p(s)p(h | f)p(a | h, s) \\
 &= \psi_{\{F, H\}}(f, h)\psi_{\{H, A, S\}}(h, a, s), \\
 \psi_{\{F, H\}}(f, h) &= p(f)p(h | f), \\
 \psi_{\{H, A, S\}}(h, a, s) &= p(s)p(a | h, s).
 \end{aligned} \tag{19.8}$$

道德图新增了 $H - S$ 边, 团势能容纳原分布, 却不再从图结构声明 $F \perp S$ 。分布中的独立性并没有消失: 对 a, h 求和仍得

$$\sum_h \sum_a p(f)p(s)p(h | f)p(a | h, s) = p(f)p(s).$$

消失的是仅靠新图就能识别该等式的能力; 它现在依赖势函数所保留的特殊归一化关系。若任意调整这两张势表而不维持这些关系, 新图允许的新分布就未必仍满足 $F \perp S$ 。

用同一组人工教学参数可以看清条件化的影响。令 $p(F = 1) = 0.1$ 、 $p(S = 1) = 0.05$, 且 $p(H = 1 | F = 1) = 0.8$ 、 $p(H = 1 | F = 0) = 0.1$, 则 $p(H = 1) = 0.17$ 。按 $(h, s) = (0, 0), (1, 0), (0, 1), (1, 1)$ 的顺序, 设 $p(A = 1 | h, s)$ 分别为 $0.01, 0.9, 0.7, 0.99$ 。这些数值不是设备实测统计。由 H 与 S 边缘独立可得

$$\begin{aligned}
 p(A = 1) &= 0.83 \times 0.95 \times 0.01 + 0.17 \times 0.95 \times 0.9 \\
 &\quad + 0.83 \times 0.05 \times 0.7 + 0.17 \times 0.05 \times 0.99 \\
 &= 0.1907.
 \end{aligned}$$

给定报警之后, 传感器状态会改变过热的后验概率:

$$\begin{aligned}
 p(H = 1 | A = 1, S = 0) &= \frac{0.17 \times 0.9}{0.17 \times 0.9 + 0.83 \times 0.01} \approx 0.9485, \\
 p(H = 1 | A = 1, S = 1) &= \frac{0.17 \times 0.99}{0.17 \times 0.99 + 0.83 \times 0.7} \approx 0.2246.
 \end{aligned} \tag{19.9}$$

这组参数确实产生了碰撞点条件化后的依赖。无论使用原有向乘积, 还是式 (19.8) 的团势乘积, 计算结果都完全相同。新增 $H - S$ 边只是使无向表示能容纳这种相互作用, 不表示转换凭空改变了物理关系。

道德化还会改变图的团结构。一个有 k 个父节点的子节点, 在道德图中与父节点构成 $k + 1$ 元团; 父节点之间可能新增至多 $\binom{k}{2}$ 条边。若各变量有 r 种状态, 任意稠密 $(k + 1)$ 元表有 r^{k+1} 个表项。不过, 这不一定是转换新带来的存储量, 因为一般的原条件概率表本来就有同样大小的作用域。多个局部作用域叠加后, 道德图的最大团还可能大于单个节点的家庭; 将小因子过早合并成一般的极大团势表, 会丢掉可利用的细分结构。

推断的实际代价取决于消除过程中形成的最大联合因子, 而不只取决

于输入图中边的数量。道德图也未必是弦图，后续消除可能继续引入填充边。因而道德化应被理解为获得一个容纳所有因子作用域的无向结构，不应被理解为已经找到代价最小的推断结构。

19.3.3 从无向因子分解到有向因子分解

任意联合分布都能用概率链式法则沿某个顺序写成条件分布乘积，但每个条件分布可能需要之前的全部变量。这只能保证存在一个稠密有向图。若希望父集仍由原无向图的邻居给出，弦图与完美消除序才提供了所需条件。

设 p 严格为正并已在弦图 $\mathcal{U}$ 上分解，选择完美消除序 $v_1, \dots, v_d$ 。下面的构造依赖一个作用域不变量：在处理 v_k 之前，每个当前因子的作用域都是剩余诱导图 $\mathcal{U}[\{v_k, \dots, v_d\}]$ 中的团。初始因子本来就定义在 $\mathcal{U}$ 的团上，因此第 1 步满足该不变量。若第 k 步开始时不变量成立，那么任何含 v_k 的当前因子，除 v_k 外只能涉及其尚未删除的邻居，因而其余作用域包含在 N_k^+ 中。将这些因子相乘并消去 v_k 后，新因子的作用域包含在 N_k^+ 中；完美消除序保证 N_k^+ 已经成团，所以新因子在下一张剩余图中仍是团因子。不含 v_k 的因子保持不变，归纳便可继续。

在第 k 步，将当前含 v_k 的因子收集到集合 $\mathcal{B}_k$ 。由上述不变量，它们的乘积只可能依赖 v_k 及 N_k^+ 中的变量。先把这些因子相乘，再对 v_k 求和：

$$\begin{aligned} b_k(x_{v_k}, \mathbf{x}_{N_k^+}) &= \prod_{\psi \in \mathcal{B}_k} \psi, \\ a_k(\mathbf{x}_{N_k^+}) &= \sum_{x_{v_k}} b_k(x_{v_k}, \mathbf{x}_{N_k^+}), \\ q_k(x_{v_k} | \mathbf{x}_{N_k^+}) &= \frac{b_k(x_{v_k}, \mathbf{x}_{N_k^+})}{a_k(\mathbf{x}_{N_k^+})}. \end{aligned} \quad (19.10)$$

这里允许函数实际依赖的变量少于所列作用域。把 $\mathcal{B}_k$ 中的因子从当前乘积移除，换入 a_k ，就完成了对 v_k 的边缘化。上述归纳同时说明，新的因子 a_k 不会要求原图之外的边。

q_k 为什么是正确的条件分布，而不仅是一张随手归一化的表？消除 $v_1, \dots, v_{k-1}$ 后，当前乘积正比于剩余变量的联合边缘分布。除 $\mathcal{B}_k$ 外的因子不含 v_k ，在给定其余剩余变量、对 v_k 归一化时都可约掉。因此 q_k 等于这个边缘分布中 v_k 给定所有剩余变量的条件分布，而式 (19.10) 表明它实际上只需要 N_k^+ 。这一步利用了消除产生的当前因子，不能只归一化输入时某张原始团势。

每一步都有 $b_k = q_k a_k$ 。把这些恒等式逐层代回，末尾消除所有变量所

留下的常数就是 Z ，故

$$\begin{aligned}\prod_{C \in \mathcal{C}} \psi_C(\mathbf{x}_C) &= Z \prod_{k=1}^d q_k(x_{v_k} | \mathbf{x}_{N_k^+}), \\ p(\mathbf{x}) &= \prod_{k=1}^d q_k(x_{v_k} | \mathbf{x}_{N_k^+}).\end{aligned}\quad (19.11)$$

以 N_k^+ 为 v_k 的父集，就得到定理 19.10 中的有向图。它的拓扑序是消除序的逆序，这两个顺序不可混用。转换后的局部条件表已经归一化，但求出这些表的过程包含了边缘化与归一化工作；全局配分函数没有凭换一种画法就变得不需要计算⁵。

若原图非弦，按照同样步骤消除变量时，其尚未删除的邻居可能不成团。乘积后求和通常会产生同时依赖这些邻居的新因子，因此要用填充边记录新作用域。对填充后的弦图应用上面的构造，可以精确保留原分布。这里的“需要填充边”是模型族层面的结论：若同一套消除与归一化构造要适用于所有按原非弦图分解的严格正分布，就必须容纳这些可能出现的中间作用域。对于某个参数已经固定的分布，中间因子可能进一步分解，甚至整个分布就是独立分布，因此不能断言每个具体分布都需要同样的边。

下面沿用例 18.13 的四节点环，把同一分布的全部转换算出来。令四个变量都取 $\{0, 1\}$ ，每条环边上的势均为

$$\psi_{\{i,j\}}(x_i, x_j) = \begin{cases} 2, & x_i = x_j, \\ 1, & x_i \neq x_j. \end{cases} \quad (19.12)$$

联合未归一化权重是四个边势的乘积。沿图 19.2 中的顺序先消除 4，得到

$$\begin{aligned}m(x_1, x_3) &= \sum_{x_4} \psi_{\{1,4\}}(x_1, x_4) \psi_{\{3,4\}}(x_3, x_4) \\ &= \begin{cases} 5, & x_1 = x_3, \\ 4, & x_1 \neq x_3. \end{cases}\end{aligned} \quad (19.13)$$

例如 $x_1 = x_3 = 0$ 时，两项分别为 2×2 和 1×1 ，和为 5；两端不同时，两项都是 2，和为 4。新的 m 依赖 1, 3，所以图中要加入 1-3 填充边。再消除 2 会产生数值相同的函数 $m(x_1, x_3)$ ，剩余权重为 $m(x_1, x_3)^2$ ，于是

$$Z = 2 \times 5^2 + 2 \times 4^2 = 82.$$

把前两步得到的局部条件分布分别记为 $q_4(x_4 | x_1, x_3)$ 与 $q_2(x_2 | x_1, x_3)$ ，这里下标直接标识变量节点。它们都由对应的两个边势相乘后除以 m 得到：若 $x_1 = x_3$ ，中间变量与它们相同的概率为 $4/5$ ，不同为 $1/5$ ；若 $x_1 \neq x_3$ ，

⁵ D. Koller, N. Friedman, *Probabilistic Graphical Models: Principles and Techniques*, MIT Press, 2009

两种取值各为 $1/2$ 。

消去 4 和 2 后, 剩余权重是 $m(x_1, x_3)^2$ 。接着消去 1, 对每个 x_3 都有

$$\sum_{x_1} m(x_1, x_3)^2 = 5^2 + 4^2 = 41,$$

所以 $q_1(x_1 | x_3) = m(x_1, x_3)^2 / 41$ 。最后剩下的权重对 $x_3 = 0, 1$ 都等于 41, 其和为 $Z = 82$, 故 $q_3(x_3) = 41/82 = 1/2$ 。于是后两个局部条件表为

$$q_3(x_3) = \frac{1}{2}, \quad q_1(x_1 | x_3) = \begin{cases} 25/41, & x_1 = x_3, \\ 16/41, & x_1 \neq x_3. \end{cases} \quad (19.14)$$

这些条件表对应父集 $\text{pa}(3) = \emptyset$ 、 $\text{pa}(1) = \{3\}$ 和 $\text{pa}(2) = \text{pa}(4) = \{1, 3\}$, 也就是边 $3 \rightarrow 1$ 、 $1 \rightarrow 2$ 、 $3 \rightarrow 2$ 、 $1 \rightarrow 4$ 和 $3 \rightarrow 4$ 。检查联合概率不需要枚举十六项, 只需观察两个 m 在乘积中约去:

$$\begin{aligned} q_3 q_1 q_2 q_4 &= \frac{1}{2} \frac{m(x_1, x_3)^2}{41} \frac{\psi_{\{1,2\}} \psi_{\{2,3\}}}{m(x_1, x_3)} \frac{\psi_{\{1,4\}} \psi_{\{3,4\}}}{m(x_1, x_3)} \\ &= \frac{\psi_{\{1,2\}} \psi_{\{2,3\}} \psi_{\{1,4\}} \psi_{\{3,4\}}}{82}. \end{aligned}$$

新增 $3 \rightarrow 1$ 并没有破坏原分布中的 $X_1 \perp X_3 \mid (X_2, X_4)$ 。例如固定 $x_2 = x_4 = 0$, 按行 $x_1 = 0, 1$ 、列 $x_3 = 0, 1$ 排列条件概率, 得到

$$[p(x_1, x_3 | X_2 = 0, X_4 = 0)] = \frac{1}{25} \begin{pmatrix} 16 & 4 \\ 4 & 1 \end{pmatrix} = \begin{pmatrix} 4/5 \\ 1/5 \end{pmatrix} \begin{pmatrix} 4/5 & 1/5 \end{pmatrix}.$$

一般给定 x_2, x_4 时, 四个原始边势也分别按 x_1 与 x_3 分组, 所以该独立性对全部条件取值成立。但新有向图无法通过 d -分离声明它, 因为 1 和 3 直接相邻。若把转换后的条件表当成彼此独立的自由参数任意修改, 这个额外等式就可能不再成立。

这个有向图还是该数值分布的最小 I-map。 q_1 随 x_3 改变; q_2 与 q_4 在固定一个父节点时, 也都随另一个父节点改变, 例如固定 $x_3 = 0$ 、将 x_1 从 0 改为 1, $q_2(X_2 = 0 | x_1, x_3)$ 便由 $4/5$ 变成 $1/2$ 。因此任意删去一条父边都会排除当前分布。但它仍漏掉原四环的一项条件独立性, 具体展示了“最小 I-map 不必是完美映射”。

参数比较必须区分输入表项数与分布族的自由度。一般离散有向图的自由参数数目为

$$\sum_{i \in V} (r_i - 1) \prod_{j \in \text{pa}(i)} r_j,$$

其中 r_i 是 X_i 的状态数; 每个父配置下的概率和为 1, 因此每行少一个自由参数。无向势表还存在因子间的重新分配冗余, 不能把各表项数直接相加

作为自由度。

表 19.1 比较的是四环的完整严格正二元图模型族，不是把式 (19.12) 中的固定数字当成待估参数。原四环可用四个一元对数项与四个边上的二元对数交互项参数化，共 8 个自由参数。填充后的有向图若允许所有条件表自由变化，则有 $1 + 2 + 4 + 4 = 11$ 个自由参数。精确转换得到的表仍受原来的 8 维模型约束，转换本身不会凭空新增自由度。

比较项	原四环的边势表示	填充后的完整有向图族
输入最大作用域	2 个变量	3 个变量
稠密表存储	$4 \times 4 = 16$ 项	$2 + 4 + 8 + 8 = 22$ 项
模型族自由度	8	11
归一化约束	全局配分函数 Z	每张条件表逐行归一化
图独立性	式 (19.5) 的两项	只保留第二项

表 19.1 四环转换的结构与参数代价。表项数按直接保存完整稠密表计算，未压缩归一化冗余；模型族自由度则已去掉冗余。精确保留原分布时，不能把新有向图的全部 11 个自由参数任意独立改变。

填充把最大团从二元扩大到三元，但不能由此说原四环的精确推断只需二元计算：原图消除 4 时就必须组合一个三元作用域，通常需要枚举 r^3 种配置，再留下 r^2 项的中间因子。填充图将这项原本就存在的计算显式化。不同消除序可能产生更大的团；若一次局部组合含 k 个各有 r 种状态的变量，稠密计算的表规模是 r^k 。因此转换可能改变输入表的存储和可见独立性，也可能暴露昂贵的中间计算，但并不保证最优推断代价必然增加或减少。

19.4 因子图

有向图强调局部条件分布，无向图强调哪些变量组可以共同出现在势函数中。真正开始计算时，程序还需要知道输入究竟是一张大表，还是若干张较小表的乘积。因子图把这一信息直接画出来，使两类模型可以进入相同的局部计算过程。

19.4.1 因子图的定义

设待计算的联合函数写为

$$g(\mathbf{x}) = \prod_{\alpha \in \mathcal{F}} f_{\alpha}(\mathbf{x}_{D_{\alpha}}), \quad D_{\alpha} \subseteq V. \quad (19.15)$$

$\mathcal{F}$ 是因子索引集， D_{α} 称为因子 f_{α} 的**作用域** (scope)，即调用这个函数需要提供的变量集合。**因子图** (factor graph) 是把变量与局部函数分别画成两类节点的二部图：一条边只表示某个变量是某个因子的输入，不表示随

机变量间的生成方向⁶。

定义 19.12 因子图 式 (19.15) 对应的因子图记为

$$\mathcal{G}_F = (V \cup \mathcal{F}, E_F), \quad E_F = \{(i, \alpha) : i \in D_\alpha\}.$$

变量节点与因子节点属于互不重叠的两类节点，只有不同类别之间可以连边。本文用圆形表示变量，用方形表示因子。

这里 g 可以是已归一化的联合概率，也可以是未归一化权重。若各因子非负且 $Z = \sum_{\mathbf{x}} g(\mathbf{x})$ 满足 $0 < Z < \infty$ ，则 $p = g/Z$ 是合法分布。常数 $1/Z$ 不依赖任何变量；若把它画成因子节点，其作用域为空，因而不连接变量，通常在图外单独记录即可。因子节点本身不是新随机变量，也不能被当作条件事件来观察或边缘化。

19.4.2 有向图和无向图的因子图表示

对有向图模型，每个节点 i 的条件分布产生一个因子 $f_i = p(x_i | \mathbf{x}_{\text{pa}(i)})$ ，它连接 i 和全部父节点。原有向图中的 $j \rightarrow i$ 并不变成变量节点间的 $j-i$ 边，而是由 $j-f_i$ 与 $i-f_i$ 等连接记录共同作用域；根节点也有自己的单变量先验因子。

报警模型的转换见图 19.4。 f_A 同时连接 H, A, S ，其中 H 与 S 作为条件输入、 A 作为被归一化的输出，这一区别保留在 $f_A(h, a, s) = p(a | h, s)$ 的函数定义里，不能只从无方向的三条连接中读出来。若只保留因子图拓扑而丢掉条件归一化信息，就不应再直接对它套用原有向图的 d-分离规则。




图 19.4 报警模型的因子图。圆形是随机变量，方形是四个局部条件或先验因子。 f_H 连接 F, H ， f_A 连接 H, A, S ；连接线表示函数输入关系，而不是有向生成边。

对 Markov 网络，每个给定的势函数产生一个因子节点，连接其作用域中的变量。若输入已经细分到边势和一元势，就应保留这些小因子，而不必为每个极大团先造一张大表。反过来，把每个因子作用域中的变量两两相连，可以得到对应的无向变量图；它记录“这些变量至少共同进入一个因子”，却会忘记相互作用到底由几个因子组成。

⁶ F. R. Kschischang, B. J. Frey, H.-A. Loeliger, *Factor Graphs and the Sum-Product Algorithm* In IEEE Transactions on Information Theory, 2001, vol. 47, no. 2, pp. 498–519

例如，三个变量的函数 $g = \psi_{\{1,2\}}\psi_{\{2,3\}}\psi_{\{1,3\}}$ 在无向变量图上表现为三角形，与一般的三元势 $\psi_{\{1,2,3\}}$ 拥有相同的完整团。但前者明确承诺可分为三个二元函数，后者未必可以。无向三角形没有条件独立性可用来区分它们；因子图却能直接显示输入分解的粒度。这是计算结构提供了额外信息，而不是因子图发现了新的普通条件独立性。

19.4.3 表示的非唯一性

同一联合函数并不确定唯一的因子图。图 19.5 把三个二元因子合成一个三元因子，乘积不变，因子图却从一个六边环变成星形。星形在拓扑上没有环，但中心因子的表规模已经从单个二元表的 r^2 增长到三元表的 r^3 ；“图无环”不能脱离因子大小单独用作计算简单的保证。




图 19.5 相同联合函数的两种因子图。左图保留三个二元因子，右图用 $f_{123} = f_{12}f_{23}f_{13}$ 将其合并。两图对应的无向变量图都是三角形；因子图的环结构和因子规模却不同。

合并总能通过乘法进行，拆分却需要函数确实具有相应结构。对于二元变量，若 $f_{12}(x_1, x_2) = u(x_1)v(x_2)$ ，其 2×2 数值表的秩至多为 1。式 (19.12) 的表为 $\begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}$ ，行列式为 3，所以不能拆成两个一元因子。任意三元势也不能仅因为画图方便，就声称可拆成三个二元势。

保持作用域不变，也可以通过**重新参数化** (reparameterization) 改变局部因子，即把一部分权重从一个因子转移到另一个因子，而保持整体乘积。例如取任意严格为正的函数 $h(x_2)$ ，令

$$\tilde{f}_{12} = f_{12}h(x_2), \quad \tilde{f}_{23} = \frac{f_{23}}{h(x_2)}.$$

两个新因子的乘积与原来完全相同。若仅把某个因子乘以正的常数，则未归一化函数 g 发生了缩放，但在同步调整 Z 后，归一化分布 p 仍相同。区分“同一联合函数”与“同一归一化分布”，有助于判断一个变换究竟保持了什么。

因子图并非完全没有独立性信息。设 $A, B, S \subseteq V$ 两两不交, 且 A, B 非空。在非负概率因子分解下, 若删除一组变量节点 S 后, A 与 B 落在不同连通分量, 则给定 $\mathbf{X}_S = \mathbf{s}$ 后, 乘积可以按这些分量分组, 归一化也按组分开, 从而推出 $\mathbf{X}_A \perp \mathbf{X}_B \mid \mathbf{X}_S$ 。该结论只对条件分布有定义的取值 $\mathbf{s}$ 使用; 在有限离散情形, 这要求 $p(\mathbf{X}_S = \mathbf{s}) > 0$ 。但这只是充分的独立性判断, 不必穷尽特定因子函数隐含的全部独立性。

报警因子图中的 $H-f_A-S$ 一直连通, 而对 $\mathbf{a}$ 求和有 $\sum_a f_A(h, \mathbf{a}, s) = 1$, 这条局部归一化约束仍能使 H 与 S 边缘独立。图拓扑自身没有记录这条等式。因此, 因子图适合保存函数作用域、安排计算; 要解释碰撞结构, 应保留原有向图及其条件分布语义, 要解释无向 Markov 约束, 则应考察相应的无向变量图。

19.4.4 因子图上的局部计算

给定证据 $\mathbf{X}_S = \mathbf{s}$ 时, 可以先把相关因子限制到该取值, 再处理其余变量。设查询节点集合为 $Q \subseteq V \setminus S$, 其余非证据节点为 $R = V \setminus (Q \cup S)$, 则未归一化的边缘函数为

$$\tilde{p}(\mathbf{x}_Q, \mathbf{s}) = \sum_{\mathbf{x}_R} \prod_{\alpha \in \mathcal{F}} f_{\alpha}(\mathbf{x}_{D_{\alpha} \setminus S}, \mathbf{s}_{D_{\alpha} \cap S}). \quad (19.16)$$

在 $p(\mathbf{s}) > 0$ 时, 把 $\tilde{p}$ 除以对 $\mathbf{x}_Q$ 的求和结果, 即得后验边缘分布。

局部计算的依据是分配律。若因子 u 不依赖待消除变量 x_i , 则 $\sum_{x_i} u v = u \sum_{x_i} v$, 因此只需收集与 x_i 相连的因子, 将它们相乘并对 x_i 求和, 再把所得函数接到剩余作用域上。式 (19.13) 正是这样的一次操作: 两个二元因子经过消除, 变为定义在 $\{1, 3\}$ 上的新因子。因子图使“收集哪些函数”“结果还依赖哪些变量”都可以由连接关系确定。

若任务是寻找全部非证据变量的最可能联合配置, 则把对这些变量配置的求和改成最大化:

$$\max_{\mathbf{x}_{V \setminus S}} \prod_{\alpha \in \mathcal{F}} f_{\alpha}.$$

这称为**最可能解释** (most probable explanation, MPE)。因为 Z 与待选配置无关, 最大化未归一化权重即可; 要恢复具体配置而不只是最大值, 还必须记录局部最大化时取得最优值的变量取值, 并在计算结束后回溯。若只对部分变量求最优、对其他未观测变量求和, 则是边缘最大后验查询 (marginal MAP), 不能把所有求和都换成最大化, 也不能随意交换两种消除顺序。

和积 (sum-product) 用乘法组合因子、用求和消除变量; **最大积** (max-product) 保留同样的乘法组合, 却用最大化消除变量。四环例子中, 若在式 (19.13) 里把求和改成最大值, 得到的函数是: 两端相同时为 4, 两端不

同时为 2，而不是原来的 5 和 4。同一组因子服务于不同查询，区别落在消除算子上。

这两类运算可统一写成**半环**（semiring）上的局部计算：用 $\otimes$ 组合局部信息，用 $\oplus$ 汇总待消除变量的不同取值。这里使用交换半环，两个运算满足结合律与交换律， $\otimes$ 对 $\oplus$ 满足分配律。再记 $e_{\oplus}$ 为 $\oplus$ 的单位元、 $e_{\otimes}$ 为 $\otimes$ 的单位元，并要求 $e_{\oplus}$ 对 $\otimes$ 具有吸收性，即 $a \otimes e_{\oplus} = e_{\oplus}$ 。于是一个局部消除结果可写为

$$h(\mathbf{x}_{D \setminus \{i\}}) = \bigoplus_{x_i} \bigotimes_{\alpha: i \in D_{\alpha}} f_{\alpha}(\mathbf{x}_{D_{\alpha}}), \quad (19.17)$$

$$D = \bigcup_{\alpha: i \in D_{\alpha}} D_{\alpha}.$$

在非负实数上， $(\oplus, \otimes) = (+, \times)$ 给出和积，此时 $(e_{\oplus}, e_{\otimes}) = (0, 1)$ ； $(\max, \times)$ 给出最大积，两个单位元仍为 0 与 1。取对数后，值域变为 $\mathbb{R} \cup \{-\infty\}$ ，最大积可改写为 $(\max, +)$ 形式，此时 $(e_{\oplus}, e_{\otimes}) = (-\infty, 0)$ ，零权重对应 $-\infty$ 。把具体运算代入同一个半环表达式，便能检验分配律为何允许相同的局部消除步骤；这种统一来自代数结构，而不是图中箭头的方向⁷。

一次消除产生的是剩余变量上的函数，不只是一个标量。把这样概括局部子问题的函数沿图传递，就是消息传递的基本计算单位。在无环因子图上，移除一条边会把计算分成两个不重叠的部分，消息可以概括其中一侧对另一侧的作用，和积因而能精确求边缘。若有环因子图上反复应用同样的局部消息更新，传回的信息可能已经包含当前节点先前发出的影响，不再具有这种不重叠保证；这就是后文环置信传播所面对的问题。另一条精确路线是先按消除序组合因子，再把形成的大团组织成适合消息传递的结构。第 20 章将展开变量消除的顺序与复杂度，第 21 章再说明如何组织和复用消息。

⁷ F. R. Kschischang, B. J. Frey, H.-A. Loeliger, *Factor Graphs and the Sum-Product Algorithm* In IEEE Transactions on Information Theory, 2001, vol. 47, no. 2, pp. 498–519

19.5 本章小结

转换图表示时，“保留分布”“保留图独立性”和“保留计算结构”是三个不同要求。I-map 只要求图声明的独立性属于分布真实独立性，即 $\mathcal{I}(\mathcal{G}) \subseteq \mathcal{I}(p)$ ；D-map 的包含方向相反。针对一个查询，先取相关祖先再道德化，可以精确复现 d-分离；将整个有向图一次性道德化，则通常只得到一个较弱的独立性描述。碰撞结构与无弦四环分别展示了两类图不能相互完美表达的情形，弦图和完美有向图则刻画了无向图可以无损保留图独立性的边界。

祖先道德图上的因子分组证明了 d-分离的可靠性；离散条件表与线性高斯参数的非平凡多项式构造，则证明了相对于这两个模型类的完备性。完备性只保证每项未分离查询都存在一个不独立的相容分布；若要让某个固定分布中的条件独立都能反推出 d-分离，还需要该分布忠实于图。

因子层面的要求较弱：有向图的条件分布可以直接作为道德图上的团因子，弦图的势函数可以沿完美消除序重组为条件分布，非弦图也能借助填充边完成精确转换。四环的数值推导说明，新图中多出的边不会自动破坏原分布已有的独立性；它只是使这些独立性不再由新图保证。把新条件表全部当成自由参数，才会扩大允许的模型族。

因子图保留的是变量与函数之间的输入关系。它既能承接有向分解，也能承接无向分解，并把求边缘与找最优配置归结为“组合局部因子，再消去变量”。同一分布可以有多种因子图，计算代价既受连接结构影响，也受因子作用域大小影响。接下来的问题因此不是寻找一种在所有方面都优于其他表示的图，而是在给定因子和查询后，选择怎样的消除顺序，才能避免生成不必要的大表。

基于变量消除的精确推断

设备发出报警以后，故障的概率是多少？如果需要给出一组最可能的故障、过热和传感器状态，又应怎样计算？第 19.4.4 节已经把两类查询归结为组合因子与消去变量，本章进一步把这一计算写成完整算法。但表示紧凑并不意味着查询容易：即使每个变量只有两个状态，直接枚举 d 个变量的全部配置也需要访问 2^d 个组合。

真正需要计算的通常不是完整联合分布，而是其中一部分变量的概率或最优配置。其余变量可以逐个消去，前提是保留它们对剩余变量的全部影响。**变量消除** (variable elimination, VE) 就是按这一原则组织局部计算的算法：收集含有某个变量的因子，把它们相乘，再通过求和、积分或最大化消去该变量。新因子替代被收集的因子，后续计算不再访问已经消去的变量。本章将说明这些替换为何保持答案、不同查询为何需要不同的消元运算，以及运算顺序怎样影响中间因子的规模。对离散表格，规模体现为状态组合数；对高斯因子，规模体现为矩阵块的维度。这一区别决定了精确推断的实际代价。

20.1 推断问题与因子运算

20.1.1 查询、证据与消元变量

把查询写清楚，才能决定哪些变量可以消去。设模型包含节点集合 V ，节点 i 对应随机变量 X_i 。用 $O \subseteq V$ 表示已经观测的节点集合，观测取值为 $\mathbf{x}_O = \mathbf{e}$ ；用 $Q \subseteq V \setminus O$ 表示希望保留的查询节点集合。其余节点组成 $R = V \setminus (O \cup Q)$ 。这里 O, Q, R 都是节点集合， $\mathbf{x}_Q$ 才是查询变量的一组取值。为避免与图的边集合 E 混淆，本章不用 E 表示证据节点。

假定模型已经给出非负因子 ψ_a ，共有 m 个，且存在有限、非零的归一化常数 Z ，使

$$p(\mathbf{x}) = \frac{1}{Z} \prod_{a=1}^m \psi_a(\mathbf{x}_{S_a}), \quad S_a \subseteq V. \quad (20.1)$$

有向图模型的因子是局部条件概率，完整模型的 $Z = 1$ ；无向模型的因子

未必归一化。推断时把这些因子及其参数视为已知，参数如何从数据估计留到第 24 章。

将观测值代入每个因子后，得到仅以未观测变量为自变量的函数

$$F_e(\mathbf{x}_{V \setminus O}) = \prod_{a=1}^m \psi_a(\mathbf{x}_{S_a}) \Big|_{\mathbf{x}_O = \mathbf{e}}. \quad (20.2)$$

本章先讨论有限离散变量。查询所需的未归一化边缘函数及其归一化形式为

$$\begin{aligned} g_Q(\mathbf{x}_Q) &= \sum_{\mathbf{x}_R} F_e(\mathbf{x}_Q, \mathbf{x}_R), \\ Z_e &= \sum_{\mathbf{x}_Q} g_Q(\mathbf{x}_Q), \\ p(\mathbf{x}_Q | \mathbf{e}) &= \frac{g_Q(\mathbf{x}_Q)}{Z_e}. \end{aligned} \quad (20.3)$$

求和下标 $\mathbf{x}_R$ 表示遍历 R 中所有变量的联合取值。因为 $Z_e = Zp(\mathbf{e})$ ，原模型的 Z 在条件概率中抵消，不必预先计算。这个比值要求 $Z_e > 0$ ；若观测事件在模型下概率为零，就不能通过归一化定义该条件分布。

连续变量的对应操作是积分。在联合密度存在且所需积分有限时，将式 (20.3) 中的求和换成积分，所得比值给出边缘条件密度。对连续观测， $p(\mathbf{e})$ 在这里指边缘密度值，不是单点事件的概率；上述密度比值只在分母有限且为正的取值处使用。这一改写统一了查询的形式，但积分能否精确完成，还取决于因子的函数形式。

20.1.2 因子乘积

局部函数的变量往往并不相同，不能把两张因子表不加区分地逐项相乘。**作用域** (scope) 记录一个因子以哪些变量为自变量；它使算法知道应该对齐哪些坐标，以及某个变量被消去后还剩哪些坐标。正式地，若 D_i 是 X_i 的取值集合，作用域为 S 的离散因子是非负函数 $\psi_S : \prod_{i \in S} D_i \rightarrow [0, \infty)$ 。实现中还要保存 S 内变量的排列及各状态的编码。同一变量在不同表中的轴位置可以不同，状态含义不能不同。

设两个因子的作用域分别为 A 和 B ，它们的乘积定义在 $A \cup B$ 上：

$$(\psi_A \psi_B)(\mathbf{x}_{A \cup B}) = \psi_A(\mathbf{x}_A) \psi_B(\mathbf{x}_B). \quad (20.4)$$

共享变量使用同一个取值，不共享的变量则扩展乘积的作用域。例如， $\psi_{\{F, H\}}(f, h)$ 与 $\psi_{\{H, S\}}(h, s)$ 的乘积以 (f, h, s) 为索引。计算其中 $(0, 1, 0)$ 一项时，访问前表的 $(0, 1)$ 项和后表的 $(1, 0)$ 项。若 F, H, S 均为二元变量，两张各有 4 项的表会产生一张有 8 项的表，而不是另一张 4 项的表。

因子不必是概率分布：单个因子的所有表项之和可以不是 1。作用域为

空的因子是一个标量，它同样属于因子乘积。这样的常数在只比较相对概率时有时可以约去，但求证据概率或比较绝对得分时必须保留。也不能因为两个因子的数值恰好相同就删除其中一个；它们是乘积中的两次出现。以下用 $\mathcal{F}$ 表示保留这些出现次数的因子集合。

20.1.3 因子约简与边缘化

观测确定了某些坐标, 可以直接读取这些坐标对应的切片。**因子约简** (factor reduction) 指把证据取值代入因子, 从其作用域中移去被固定的变量。例如, 将 $A = 1$ 代入报警因子 $p(a | h, s)$, 得到 $\ell_A(h, s) = p(A = 1 | h, s)$ 。这个函数衡量不同 (h, s) 对已发生报警的支持程度, 通常既不是 $p(h, s)$, 也不是 $p(h, s | A = 1)$ 。后验还需要结合先验与其他因子。

没有观测的变量不能通过选取某一个切片来删除。要计算其余变量的概率, 需要把该变量的所有可能状态累加。**边缘化** (marginalization) 就是这种汇总操作: 若 $i \in S$, 则

$$(\sum_{x_i} \psi_S)(\mathbf{x}_{S \setminus \{i\}}) = \sum_{x_i \in D_i} \psi_S(\mathbf{x}_{S \setminus \{i\}}, x_i). \quad (20.5)$$

约简是在一个已知取值处读取函数, 边缘化则汇总一个未知变量的全部取值。两者都会缩小作用域, 却回答不同的问题。

在整组因子上消去 x_i , 必须先收集所有含有 x_i 的因子。若它同时出现在 $\psi_1(x_i, y)$ 和 $\psi_2(x_i, z)$ 中, 所需结果为 $\sum_{x_i} \psi_1(x_i, y) \psi_2(x_i, z)$, 不能改成两个和的乘积。后一种计算允许两张表分别选取不同的 x_i , 破坏了它们共享同一个变量的约束。每次正确消元只去掉一个变量, 却把它与其他变量共同产生的影响留在新因子中。

归一化通常放在所有非查询变量消去之后。若将中间因子除以一个与其所有自变量无关的正常数, 最终条件分布不变, 但要计算 Z_e 就需记录并补回这个常数。若按每一行分别归一化, 除数随剩余变量改变, 就会改变不同查询配置的相对权重, 不能把它当成无害的数值处理。

20.2 边缘概率的变量消除算法

20.2.1 从朴素枚举到分配律

继续使用设备故障教学模型。 F 表示故障, H 表示过热, A 表示报警, S 表示传感器失灵, 四者均取 0 或 1。模型的分解为

$$p(f, h, a, s) = p(f)p(h | f)p(s)p(a | h, s). \quad (20.6)$$

图中的有向边为 $F \rightarrow H \rightarrow A \leftarrow S$, 两个根节点 F, S 独立。设 $p(F = 1) = 0.1$ 、 $p(S = 1) = 0.05$, 并令

$$p(H = 1 \mid F = 0) = 0.1, \quad p(H = 1 \mid F = 1) = 0.8.$$

报警的条件概率见表 20.1。这些数值是用于解释算法的人工设置, 并非真实设备的统计结果; 每个二元分布中状态 0 的概率由 1 减去状态 1 的概率得到。

h	s	$p(A = 1 \mid h, s)$
0	0	0.01
1	0	0.90
0	1	0.70
1	1	0.99

表 20.1 报警教学模型的条件概率表。表中的每一行在固定 (h, s) 后给出报警概率, 未列出的不报警概率为其补数。

观测到 $A = 1$ 以后, 故障查询的未归一化函数是

$$g_F(f) = \sum_h \sum_s p(f)p(h \mid f)p(s)\ell_A(h, s).$$

朴素枚举会对每个 f 访问全部 (h, s) 组合。虽然此例只有 8 个三元配置, 但其中 $p(s)\ell_A(h, s)$ 与 f 无关, 会被重复计算。乘法对加法的分配律允许把与当前求和变量无关的因子移到求和号外:

$$g_F(f) = p(f) \sum_h p(h \mid f) \underbrace{\sum_s p(s)\ell_A(h, s)}_{\tau_S(h)}. \quad (20.7)$$

新因子 $\tau_S(h)$ 只需计算一次, 它替代 $p(s)$ 和 $\ell_A(h, s)$, 供所有 f 共享。再将 $p(h \mid f)\tau_S(h)$ 对 h 求和, 得到只依赖 f 的因子。图 20.1 展示了这一过程中的作用域变化。

节省来自共享局部计算, 不来自删除概率较小的状态。每个状态仍按其原有权重参与求和, 所以代数上没有近似误差。如果消去某个变量时必须把几乎所有剩余变量连到同一个因子中, 分配律虽然依然成立, 却未必能带来可承受的存储量。消元顺序的作用正是在这里体现出来。

20.2.2 变量消除算法

将上述变形推广到任意因子分解, 需要在每一步明确哪些因子被替换。设 $\mathcal{F}^{(0)}$ 为约简后的初始因子集合, 消元顺序 $\pi = (i_1, \dots, i_k)$ 包含 R 中的每个




图 20.1 报警查询的局部消元。上部为原有向图，方形节点表示已观测的 $A=1$ ；红色节点 S, H 与下方红框求和符号逐步对应。下部先对 s 求和形成 $\tau_S(h)$ ，再对 h 求和形成 $\tau_H(f)$ ；每一行的输出不再包含被消去的变量，查询变量 F 一直保留。

节点且恰好一次。第 t 步处理 X_{i_t} ，把含有它的因子收集为

$$\mathcal{B}_t = \{\psi \in \mathcal{F}^{(t-1)} : i_t \in \text{scope}(\psi)\}.$$

这里 $\text{scope}(\psi)$ 表示 ψ 的作用域。这个集合也称为当前变量的桶 (bucket)，即本步必须共同处理的全部因子。令 U_t 为桶内作用域的并集， $N_t = U_t \setminus \{i_t\}$ ，则本步的局部乘积和输出为

$$\begin{aligned} \phi_t(\mathbf{x}_{U_t}) &= \prod_{\psi \in \mathcal{B}_t} \psi, \\ \tau_t(\mathbf{x}_{N_t}) &= \sum_{\mathbf{x}_{i_t}} \phi_t(\mathbf{x}_{U_t}). \end{aligned} \quad (20.8)$$

乘积中的每个因子都按式 (20.4) 对齐坐标。桶外因子不含 X_{i_t} ，因此保持不动。

算法 20.1 离散边缘概率的变量消除

输入： 非负有限因子 $\{\psi_a\}$ ，证据 $\mathbf{x}_0 = \mathbf{e}$ ，查询集 Q

输入： $R = V \setminus (O \cup Q)$ 的排列 $\pi = (i_1, \dots, i_k)$

输出： 查询因子 g_Q 及 $Z_{\mathbf{e}} > 0$ 时的条件分布

- 1: 将证据代入各因子，得到 $\mathcal{F}^{(0)}$ ；保留标量因子
- 2: 对未出现在任何作用域中的未观测变量，加入其恒为 1 的一元因子
- 3: **for** $t = 1, \dots, k$ **do**
- 4: 收集 $\mathcal{B}_t$ ，令 U_t 为其作用域的并集

```

5:   对齐坐标并求乘积  $\phi_t = \prod_{\psi \in \mathcal{B}_t} \psi$ 
6:   对  $x_{i_t}$  求和, 得到  $\tau_t(\mathbf{x}_{U_t \setminus \{i_t\}})$ 
7:    $\mathcal{F}^{(t)} \leftarrow (\mathcal{F}^{(t-1)} \setminus \mathcal{B}_t) \cup \{\tau_t\}$ 
8: end for
9: 在查询取值空间上计算  $g_Q = \prod_{\psi \in \mathcal{F}^{(k)}} \psi$ 
10: 计算  $Z_e = \sum_{\mathbf{x}_Q} g_Q(\mathbf{x}_Q)$ 
11: if  $Z_e = 0$  then
12:   返回证据与模型不相容, 条件分布未定义
13: else
14:   返回  $g_Q$ 、 $Z_e$  及  $g_Q/Z_e$ 
15: end if

```

算法 20.1 中的移除和加入按因子的出现次数操作。添加恒为 1 的一元因子, 是为了覆盖某变量没有实际进入任何因子的退化情形: 它被求和时仍应贡献其状态数。 R 为空时, 循环直接跳过; Q 为空时, 最终因子是标量 Z_e , 对应证据的未归一化权重。输出条件分布时只需要保留最终查询因子, 不需要恢复已求和变量的某一组取值, 因为这些变量的所有可能状态已经被累加。

在报警例中, 初始因子为 $p(f)$ 、 $p(h | f)$ 、 $p(s)$ 、 $\ell_A(h, s)$ 。先消去 S , 桶中只有 $p(s)$ 和 $\ell_A(h, s)$, 故

$$\begin{aligned}\tau_S(0) &= 0.95 \times 0.01 + 0.05 \times 0.70 = 0.0445, \\ \tau_S(1) &= 0.95 \times 0.90 + 0.05 \times 0.99 = 0.9045.\end{aligned}\tag{20.9}$$

移除这两个因子后, 当前因子集合变为 $\{p(f), p(h | f), \tau_S(h)\}$ 。消去 H 时, 收集 $p(h | f)$ 和 $\tau_S(h)$, 得到

$$\begin{aligned}\tau_H(0) &= 0.9 \times 0.0445 + 0.1 \times 0.9045 = 0.1305, \\ \tau_H(1) &= 0.2 \times 0.0445 + 0.8 \times 0.9045 = 0.7325.\end{aligned}\tag{20.10}$$

此时只剩 $p(f)$ 和 $\tau_H(f)$ 。相乘得到 $g_F(0) = 0.11745$ 、 $g_F(1) = 0.07325$, 两项之和为 0.19070。由于这个有向图模型本来就已归一化, 这个和恰好是 $p(A = 1)$ 。条件故障概率为

$$p(F = 1 | A = 1) = \frac{0.07325}{0.19070} \approx 0.384111.\tag{20.11}$$

报警把故障概率从 0.1 提高到约 0.384, 但没有把它提高到 1。模型还允许无故障过热、传感器失灵及小概率误报; 这些不同解释都通过求和保留在分母中。

整个计算只生成了 $\tau_S(h)$ 和 $\tau_H(f)$ 两张一元表。在更大的模型中, 同样可以预先按顺序分桶: 一个因子交给其作用域中最早被消去的变量, 新因子再移交给后续桶。因子收集、合并和消元构成的统一算法框架可参见

Dechter 的桶消除论述¹。

¹ R. Dechter, *Bucket Elimination: A Unifying Framework for Reasoning In Artificial Intelligence*, 1999, vol. 113, pp. 41–85

20.2.3 多变量查询

如果既关心故障，也关心传感器是否失灵，应保留 $Q = \{F, S\}$ ，只消去 H 。结果不是两张独立的一元分布，而是一张描述两者联合状态的表：

$$g_{F,S}(f, s) = p(f)p(s) \sum_h p(h | f) \ell_A(h, s). \quad (20.12)$$

例如，其中一个联合状态的权重为

$$\begin{aligned} g_{F,S}(0, 0) &= 0.9 \times 0.95 \times (0.9 \times 0.01 + 0.1 \times 0.90) \\ &= 0.084645. \end{aligned}$$

其余三项按同样方式得到表 20.2。

f	$g_{F,S}(f, 0)$	$g_{F,S}(f, 1)$
0	0.084645	0.032805
1	0.068590	0.004660

表 20.2 观测报警后保留 F, S 得到的未归一化联合表。四项共同除以 0.19070 才得到 $p(f, s | A = 1)$ ；逐行归一化会得到不同的条件分布。

表中四项之和仍为 0.19070。对每行求和恢复 $g_F(f)$ ；对每列求和得到 $g_S(s)$ 。虽然 F, S 在观测前独立，报警证据会使它们相关：一种报警解释的可信度会影响另一种解释的相对权重。因此，不能把分别算出的一元后验直接相乘来替代联合查询。即使消元过程中的各个桶都很小，只要要求显式输出多个查询变量的联合表，输出本身仍可能非常大。

20.2.4 连续变量的边缘消除

对非负连续因子，分配律仍允许把与当前积分变量无关的因子移出积分号；非负性保证可以用 Tonelli 定理交换积分次序。若目标是一个正常的条件密度，还要另外要求归一化积分有限且为正。真正新增的困难是函数表示：一般函数积分后未必仍能由有限个参数精确表示，数值求积也会引入近似。高斯因子是一个重要的可解析情形，因为二次型指数函数相乘或边缘化之后仍保留同类形式。

设 $\mathbf{x} \in \mathbb{R}^q$ 。为了让乘积容易计算，把高斯因子写成**规范形式** (canonical form)，即用二次项、一次项和常数项的系数表示它：

$$\psi(\mathbf{x}) = \exp\left\{-\frac{1}{2}\mathbf{x}^\top \mathbf{J} \mathbf{x} + \mathbf{h}^\top \mathbf{x} + c\right\}. \quad (20.13)$$

这里 $\mathbf{J} \in \mathbb{R}^{q \times q}$ 是对称矩阵， $\mathbf{h} \in \mathbb{R}^q$ ， c 是标量。若该因子是均值为 $\boldsymbol{\mu}$ 、协

方差为 Σ 的非退化高斯密度, $\mathbf{J} = \Sigma^{-1}$ 称为**精度矩阵** (precision matrix), 它以逆协方差的方式表示二次约束强度; $\mathbf{h} = \mathbf{J}\boldsymbol{\mu}$, 且 c 还包括归一化常数。单个局部因子可以在某些方向上没有约束, 不要求它独立归一化; 这里要求组合后的联合精度矩阵正定, 从而表示一个可归一化的非退化高斯分布。

两个规范形式因子相乘, 只需先对齐坐标, 再把相应的 $\mathbf{J}$ 、 $\mathbf{h}$ 和 c 相加。一个因子不涉及的变量坐标补零, 这与离散因子乘积时扩展作用域相对应。连续证据的吸收也是代入取值。例如, 将变量分为保留块 $\mathbf{x}_A$ 和观测块 $\mathbf{x}_O = \mathbf{e}$ 后, 约简因子的参数为

$$\begin{aligned}\mathbf{J}' &= \mathbf{J}_{A,A}, \\ \mathbf{h}' &= \mathbf{h}_A - \mathbf{J}_{A,O}\mathbf{e}, \\ c' &= c + \mathbf{h}_O^\top \mathbf{e} - \frac{1}{2} \mathbf{e}^\top \mathbf{J}_{O,O} \mathbf{e}.\end{aligned}$$

注意, 这只是固定观测坐标, 还没有消去任何未知变量。

下面推导一次积分消元。把桶内因子的乘积写成式 (20.13), 将作用域分为要消去的块 B 和保留块 A 。令 $\mathbf{y} = \mathbf{x}_B \in \mathbb{R}^b$ 、 $\mathbf{z} = \mathbf{x}_A \in \mathbb{R}^a$, 相应参数分块为

$$\mathbf{J} = \begin{pmatrix} \mathbf{J}_{B,B} & \mathbf{J}_{B,A} \\ \mathbf{J}_{A,B} & \mathbf{J}_{A,A} \end{pmatrix}, \quad \mathbf{h} = \begin{pmatrix} \mathbf{h}_B \\ \mathbf{h}_A \end{pmatrix}.$$

为使关于 $\mathbf{y}$ 的积分有限, 假设 $\mathbf{J}_{B,B} > 0$ 。在非退化联合高斯模型的精确消元过程中, 当前完整精度矩阵及后续 Schur 补保持正定; 所有包含 $\mathbf{y}$ 的二次项都已收集进桶, 因此其主块满足这一条件。

指数中涉及 $\mathbf{y}$ 的部分为

$$-\frac{1}{2} \mathbf{y}^\top \mathbf{J}_{B,B} \mathbf{y} + \mathbf{y}^\top (\mathbf{h}_B - \mathbf{J}_{B,A} \mathbf{z}).$$

令 $\mathbf{u}(\mathbf{z}) = \mathbf{h}_B - \mathbf{J}_{B,A} \mathbf{z}$, 通过配方把它改写为

$$\begin{aligned}-\frac{1}{2} (\mathbf{y} - \mathbf{J}_{B,B}^{-1} \mathbf{u})^\top \mathbf{J}_{B,B} (\mathbf{y} - \mathbf{J}_{B,B}^{-1} \mathbf{u}) \\ + \frac{1}{2} \mathbf{u}^\top \mathbf{J}_{B,B}^{-1} \mathbf{u}.\end{aligned} \tag{20.14}$$

第一项是一个平移后的高斯核, 其积分为 $(2\pi)^{b/2} |\mathbf{J}_{B,B}|^{-1/2}$; 第二项与 $\mathbf{y}$ 无关, 留在结果中。把 $\mathbf{u}$ 展开, 按 $\mathbf{z}$ 的二次项、一次项和常数项重新收集,

得到

$$\begin{aligned} \mathbf{J}' &= \mathbf{J}_{A,A} - \mathbf{J}_{A,B} \mathbf{J}_{B,B}^{-1} \mathbf{J}_{B,A}, \\ \mathbf{h}' &= \mathbf{h}_A - \mathbf{J}_{A,B} \mathbf{J}_{B,B}^{-1} \mathbf{h}_B, \\ c' &= c + \frac{1}{2} \mathbf{h}_B^\top \mathbf{J}_{B,B}^{-1} \mathbf{h}_B \\ &\quad + \frac{b}{2} \log(2\pi) - \frac{1}{2} \log |\mathbf{J}_{B,B}|. \end{aligned} \quad (20.15)$$

因此，积分后的因子仍是 $\exp\{-\mathbf{z}^\top \mathbf{J}' \mathbf{z} / 2 + \mathbf{h}'^\top \mathbf{z} + c'\}$ 。这里的 $\mathbf{J}'$ 称为 $\mathbf{J}_{B,B}$ 在 $\mathbf{J}$ 中的 **Schur 补** (Schur complement)，它把被消去块对保留块的影响合并进一个较小的矩阵。只删除精度矩阵的行列会遗漏减去的这一项，得到的是不同的运算。用协方差表示时，取边缘确实只需取对应主块；用精度表示时必须计算 Schur 补，两种参数化不可混用。

对完整的正定联合精度矩阵，Schur 补仍为正定。事实上，对任意 $\mathbf{z} \neq \mathbf{0}$ 取 $\mathbf{y} = -\mathbf{J}_{B,B}^{-1} \mathbf{J}_{B,A} \mathbf{z}$ ，则

$$\begin{pmatrix} \mathbf{y} \\ \mathbf{z} \end{pmatrix}^\top \mathbf{J} \begin{pmatrix} \mathbf{y} \\ \mathbf{z} \end{pmatrix} = \mathbf{z}^\top \mathbf{J}' \mathbf{z} > 0.$$

因此最终查询高斯核可以归一化，其均值和协方差分别为 $(\mathbf{J}')^{-1} \mathbf{h}'$ 与 $(\mathbf{J}')^{-1}$ 。这一正定性结论针对完整当前联合矩阵；单个尚未结合其他因子的桶输出不必独立可归一化。

这个式子也直接联系到线性方程消元。规范形式高斯的均值满足 $\mathbf{J}\boldsymbol{\mu} = \mathbf{h}$ 。其 B 块方程给出 $\boldsymbol{\mu}_B = \mathbf{J}_{B,B}^{-1}(\mathbf{h}_B - \mathbf{J}_{B,A}\boldsymbol{\mu}_A)$ ，代入 A 块方程即得 $\mathbf{J}'\boldsymbol{\mu}_A = \mathbf{h}'$ 。概率边缘化与块高斯消元采用相同的 Schur 补更新，但概率计算还需要 c' 中的行列式项来追踪质量。高斯模型的这类消元关系可参见 Lauritzen 的系统论述²。

² S. L. Lauritzen, *Graphical Models*, Clarendon Press, 1996

示例 20.1 一个二维高斯核的积分 考虑 $\mathbf{x} = (x_1, x_2)^\top$ ，令

$$\mathbf{J} = \begin{pmatrix} 2 & -1 \\ -1 & 2 \end{pmatrix}, \quad \mathbf{h} = \begin{pmatrix} 1 \\ 0 \end{pmatrix}, \quad c = 0.$$

该精度矩阵的特征值为 1, 3，因此核可归一化。消去 x_1 时， $\mathbf{J}_{B,B} = 2$ 、 $\mathbf{J}_{B,A} = -1$ 。式 (20.15) 给出

$$\mathbf{J}' = \frac{3}{2}, \quad \mathbf{h}' = \frac{1}{2}, \quad c' = \frac{1}{4} + \frac{1}{2} \log \pi.$$

积分结果为

$$\tau(x_2) = \sqrt{\pi} \exp\left\{\frac{1}{4} - \frac{3}{4}x_2^2 + \frac{1}{2}x_2\right\}.$$

将它归一化，得到 $x_2 \sim \mathcal{N}(1/3, 2/3)$ 。另一方面，

$$\mathbf{J}^{-1} = \frac{1}{3} \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}, \quad \mathbf{J}^{-1} \mathbf{h} = \begin{pmatrix} 2/3 \\ 1/3 \end{pmatrix}.$$

联合分布的均值和协方差主块给出相同结果。若误把边缘精度写成原来的 $\mathbf{J}_{2,2} = 2$ ，则会错误地得到方差 $1/2$ 。

高斯消元的“精确”依赖于闭包性，而不是连续变量可以按有限状态枚举。若含有离散潜变量，每个离散配置下分别是高斯，求和后一般会成为高斯混合；混合分量数可能随消元增长。若含有非二次的势函数，也不能直接套用式 (20.15)。把积分改为数值求积或把混合压缩成单个高斯，都是额外近似，必须与本节的解析消元区分。

20.3 MPE 与 MAP 的变量消除算法

给定证据后，MPE 最大化全部未观测变量，要求恢复一组完整的联合最优配置；MAP 只最大化指定的目标变量，并对其余未观测变量求和。两类查询都能复用变量消除的局部计算框架，但 MPE 的消元阶段只有最大化，MAP 则必须保留“先对非目标未观测变量求和，再对目标变量最大化”的运算顺序。这个差别也决定了回溯语义：MPE 恢复全部未观测变量，MAP 只恢复目标变量，已经求和消去的变量没有对应的最优状态。

20.3.1 MPE 变量消除

概率分布回答每种状态有多可信；有时任务还要求选出一组完整解释。给定证据后，**最可能解释**（most probable explanation, MPE）指全部非证据变量的联合最优配置，而不是逐个变量分别选取边缘概率最大的状态。令 $U = V \setminus O$ ，其目标为

$$\begin{aligned} \mathbf{x}_U^* &\in \arg \max_{\mathbf{x}_U} p(\mathbf{x}_U \mid \mathbf{e}) \\ &= \arg \max_{\mathbf{x}_U} F_{\mathbf{e}}(\mathbf{x}_U). \end{aligned} \quad (20.16)$$

由于分母 $Z_{\mathbf{e}}$ 是与候选配置无关的正常数，寻找最优配置不必计算它。若还要报告该配置的后验概率，则必须另外求出 $Z_{\mathbf{e}}$ 。

对非负函数，与 x_i 无关的乘数可以移出最大化：

$$\max_{x_i} \{\rho(\mathbf{z}) \phi(x_i, \mathbf{z})\} = \rho(\mathbf{z}) \max_{x_i} \phi(x_i, \mathbf{z}), \quad \rho(\mathbf{z}) \geq 0.$$

因此，可以沿用边缘 VE 的收集与替换流程，只把局部求和改为最大化。不

同之处在于，最大值并没有记录由哪一个 x_i 取得。为了恢复解释，每次最大化都要保存一张**回溯表**（backpointer table），它针对剩余变量的每组取值，记录当前变量应取哪个最优状态：

$$\begin{aligned}\tau_t(\mathbf{x}_{N_t}) &= \max_{x_{i_t}} \phi_t(x_{i_t}, \mathbf{x}_{N_t}), \\ b_t(\mathbf{x}_{N_t}) &\in \arg \max_{x_{i_t}} \phi_t(x_{i_t}, \mathbf{x}_{N_t}).\end{aligned}\quad (20.17)$$

若多个状态并列最优，可按预先约定的状态顺序选一个。只保存一个选择可以恢复一个最优配置；要枚举所有最优配置，则需保留所有并列选择，输出数量本身也可能很大。

算法 20.2 MPE 消元及配置回溯

输入： 约简后的非负因子 $\mathcal{F}^{(0)}$ 及 U 的排列 π
输入： 各变量取值有限， $Z_e > 0$ ，每个变量有对应作用域
输出： 最优配置 $\mathbf{x}_U^*$ 及未归一化得分 v^*

- 1: **for** $t = 1, \dots, |U|$ **do**
- 2: 收集含 X_{i_t} 的因子，形成局部乘积 ϕ_t
- 3: 令 $N_t = \text{scope}(\phi_t) \setminus \{i_t\}$
- 4: 按式 (20.17) 计算 τ_t 和 b_t
- 5: 用 τ_t 替换桶内因子，并保存 (i_t, N_t, b_t)
- 6: **end for**
- 7: 将剩余标量因子相乘，得到 v^*
- 8: **for** $t = |U|, \dots, 1$ **do**
- 9: $x_{i_t}^* \leftarrow b_t(\mathbf{x}_{N_t}^*)$
- 10: **end for**
- 11: 返回 $\mathbf{x}_U^*$ 和 v^*

回溯必须与消元顺序相反。第 t 步输出因子只涉及尚未消去的变量，所以 N_t 内的变量一定出现在 i_t 之后；逆序恢复时，它们已经有了确定取值。最后被消去的变量的回溯表以空配置为索引，直接给出一个状态。由它出发逐步查表，便能恢复完整配置，无须重新搜索所有状态。

报警模型给出一个可以逐项核验的过程。仍按 S, H, F 的顺序消元，但用最大值替代求和。消去 S 得到

$$\begin{aligned}\tau_S^{\max}(0) &= \max\{0.0095, 0.0350\} = 0.0350, \\ \tau_S^{\max}(1) &= \max\{0.8550, 0.0495\} = 0.8550.\end{aligned}$$

对应的回溯表为 $b_S(0) = 1$ 、 $b_S(1) = 0$ 。在 $H = 0$ 时，传感器失灵是较好的报警解释；在 $H = 1$ 时，传感器正常反而更有可能。这个选择依赖于尚未确定的 H ，因此此时不能只保留某个全局固定的 s_0 。

继续消去 H ，对 $f = 0$ 比较 $0.9 \times 0.0350 = 0.0315$ 与 $0.1 \times 0.8550 = 0.0855$ ，

故 $\tau_H^{\max}(0) = 0.0855$ 、 $b_H(0) = 1$ 。对 $f = 1$ 比较 $0.2 \times 0.0350 = 0.0070$ 与 $0.8 \times 0.8550 = 0.6840$ ，故 $\tau_H^{\max}(1) = 0.6840$ 、 $b_H(1) = 1$ 。消去 F 时再比较

$$\begin{aligned} p(F=0)\tau_H^{\max}(0) &= 0.07695, \\ p(F=1)\tau_H^{\max}(1) &= 0.06840. \end{aligned}$$

最大值来自 $f^* = 0$ 。逆序查表得到 $h^* = b_H(0) = 1$ 、 $s^* = b_S(1) = 0$ ，故最可能解释为 $(F, H, S) = (0, 1, 0)$ 。代回原模型，其联合证据权重为 $0.9 \times 0.1 \times 0.95 \times 0.9 = 0.07695$ ，与消元结果相同；后验概率约为 $0.07695/0.19070 = 0.403513$ 。

这里“无故障却过热”不是逻辑矛盾，模型明确给它分配了正概率。MPE 选择的是一组完整状态，其后验概率约为 0.404，而不是声称这组状态确定发生。也不能把 $\tau_t^{\max}$ 按表项总和归一化后称为边缘概率：这些表保存的是最佳完成配置的权重，不是所有完成配置的概率总和。

算法 20.2 以有限离散状态为前提。连续变量可以在最大值存在且局部优化能够精确完成时使用同类思想。对正定高斯核，式 (20.14) 表明局部最优值为 $\mathbf{y}^* = \mathbf{J}_{B,B}^{-1}(\mathbf{h}_B - \mathbf{J}_{B,A}\mathbf{z})$ ，回溯对象是这个仿射函数；二次项与一次项的更新仍是 Schur 补，但最大化不产生积分中的 $(b/2)\log(2\pi) - (1/2)\log|\mathbf{J}_{B,B}|$ 。一般连续密度未必有可达到的最大值，而且密度众数依赖坐标参数化，不能把它直接解释成单点事件的最大概率。

20.3.2 MAP 变量消除

如果诊断只要求选择故障状态，过热和传感器状态并不需要共同作答，那么完整解释的最大值就不是目标。此时应把未要求回答的变量边缘化，再比较剩余配置。**边缘最大后验推断** (marginal maximum a posteriori inference, marginal MAP) 寻找部分目标变量的联合后验众数：它对其他未观测变量的各种解释求和，而不是只保留其中最有利的一种。令 $M \subseteq V \setminus O$ 为 MAP 目标集合， $R = V \setminus (O \cup M)$ ，则

$$\mathbf{x}_M^* \in \arg \max_{\mathbf{x}_M} \sum_{\mathbf{x}_R} F_e(\mathbf{x}_M, \mathbf{x}_R). \quad (20.18)$$

MPE 是 $M = V \setminus O$ 、 $R = \emptyset$ 时的特殊情形。术语“MAP”在不同文献中有时也包含 MPE；本节用“边缘 MAP”明确表示同时含求和与最大化的查询。

边缘 MAP 不能随意把每个变量的聚合运算交换位置。表 20.3 给出一个二元目标变量 X 与一个二元未观测变量 Y 的人工联合分布，无额外证据。

正确的运算为 $\max_x \sum_y p(x, y) = \max\{0.45, 0.55\} = 0.55$ ，选择 $x^* = 1$ 。交换运算后却得到 $\sum_y \max_x p(x, y) = 0.40 + 0.27 = 0.67$ 。后一计算在 $Y = 0$

x	$p(x, Y = 0)$	$p(x, Y = 1)$	$\sum_y p(x, y)$
0	0.40	0.05	0.45
1	0.28	0.27	0.55

表 20.3 求和与最大化不可交换的反例。边缘 MAP 在累加每行后选择 $X = 1$ ；MPE 选择概率最大的单元格 $(X, Y) = (0, 0)$ ，其 X 分量并非边缘 MAP 答案。

时选择 $X = 0$ ，在 $Y = 1$ 时选择 $X = 1$ ，允许答案随那个本应被边缘化的未知变量改变。它把两个不相容的目标状态的收益加在一起，不能恢复成一个具有该概率的固定 x 。同一表还说明，先求 MPE 再丢弃不关心的分量也可能选错：MPE 的 $X = 0$ ，边缘 MAP 的 $X = 1$ 。

对任意有限非负表 $f(x, y)$ ，这一关系可写为

$$\max_x \sum_y f(x, y) \leq \sum_y \max_x f(x, y). \quad (20.19)$$

证明只需固定左边的一个最优 x^* ：对每个 y 都有 $f(x^*, y) \leq \max_x f(x, y)$ ，逐项相加即得不等式。等号成立当且仅当存在同一个 x^* ，对所有 y 都达到该列的最大值；因为各项差值非负，总差为零就要求每项差都为零。表 20.3 的两列没有共同的最大化状态，因此不等式严格成立。

一个通用且保证正确的顺序是：先消去 R 中所有要求和的变量，再消去 M 中所有要最大化的变量。求和阶段完全沿用算法 20.1 的桶操作，但不需要在两个阶段之间归一化或强制合并成一张完整的 M 表；保留剩余因子分解即可。最大化阶段采用算法 20.2 的局部最大值和回溯表，逆序恢复的只有 M 内的变量。 R 已经被边缘化，算法不为这些变量指定状态。

这条顺序规则是一般保证，不是说每一对求和、最大化在每个具体问题里都绝对不能交换。若当前目标分解为 $f(x)g(y, z)$ ，非负性允许 $\max_x$ 与 $\sum_y$ 在这两个独立部分上交换；共同最大化状态等数值结构也可能带来例外。但若只根据任意非负因子的作用域生成通用算法，不能在检查的情况下假定这些条件成立。错误换序有时能给出式 (20.19) 意义上的上界，却不再是精确 MAP 答案。边缘 MAP 的顺序约束及其计算困难可参见 Park 与 Darwiche 的分析³。

在报警例中，若 MAP 目标为 F ，则对 S, H 求和后比较 $g_F(0) = 0.11745$ 和 $g_F(1) = 0.07325$ ，选择 $F = 0$ 。若目标改为 (F, S) ，则应先对 H 求和，得到表 20.2。随后先最大化 F ：在 $s = 0$ 时保留 0.084645 并记录 $b_F(0) = 0$ ，在 $s = 1$ 时保留 0.032805 并记录 $b_F(1) = 0$ 。再最大化 S 得到 $s^* = 0$ ，逆序查表恢复 $f^* = b_F(0) = 0$ 。这里只恢复目标 (F, S) ，不为已经求和的 H 指定状态。

这些答案在本例中恰与 MPE 的相应分量一致，表 20.3 说明这种一致不是一般性质。查询集合不仅影响输出，还限制了哪些消元顺序可用；即使

³ J. D. Park, A. Darwiche, *Complexity Results and Approximation Strategies for MAP Explanations* In *Journal of Artificial Intelligence Research*, 2004, vol. 21, pp. 101–133

原图很稀疏，受限顺序也可能产生大因子。

20.4 算法分析

20.4.1 算法正确性

局部公式看起来合理，还需要证明连续多次替换不会丢失全局信息。关键是一个逐步保持的等式：当前因子乘积已经包含被消去变量的全部聚合结果。令 $I_t = \{i_1, \dots, i_t\}$ 、 $I_0 = \emptyset$ ，用 $P^{(t)} = \prod_{\psi \in \mathcal{F}^{(t)}} \psi$ 表示第 t 步之后当前因子的乘积。

定理 20.2 同类消元的不变式 设 $U = V \setminus O$ 为有限非观测节点集， X_i 的状态空间为 $\mathcal{X}_i$ ；对 $A \subseteq U$ 记 $\mathcal{X}_A = \prod_{i \in A} \mathcal{X}_i$ ，空指标集采用单点空间。令 $\pi = (i_1, \dots, i_k)$ 为 U 中互异节点的消元序列，并令 $I_0 = \emptyset$ 、 $I_t = \{i_1, \dots, i_t\}$ 。初始因子多重集 $\mathcal{F}^{(0)}$ 中的因子均取有限非负值，其乘积为 F_e 。第 t 步令 $\mathcal{B}_t = \{\psi \in \mathcal{F}^{(t-1)} : i_t \in \text{scope}(\psi)\}$ 、 $N_t = (\bigcup_{\psi \in \mathcal{B}_t} \text{scope}(\psi)) \setminus \{i_t\}$ 和 $\phi_t = \prod_{\psi \in \mathcal{B}_t} \psi$ ，以对 X_{i_t} 精确求和、积分或最大化所得的新因子替换 $\mathcal{B}_t$ ，并保留所有标量因子。记 $\mathcal{F}^{(t)}$ 为更新后的因子多重集， $P^{(t)} = \prod_{\psi \in \mathcal{F}^{(t)}} \psi$ 。

若每个变量的状态空间有限非空，则对每个 $t = 0, \dots, k$ ，求和消元满足

$$P^{(t)}(\mathbf{x}_{(V \setminus O) \setminus I_t}) = \sum_{\mathbf{x}_{I_t}} F_e(\mathbf{x}_{V \setminus O}).$$

对积分消元，设每个 $(\mathcal{X}_i, \mathcal{A}_i)$ 带有 σ 有限基准测度 μ_i ，各因子非负可测；对 $A \subseteq U$ 记 $\mu_A = \bigotimes_{i \in A} \mu_i$ ，空指标集采用单位测度。要求对每个 $t = 1, \dots, k$ ，局部输出

$$\tau_t(\mathbf{x}_{N_t}) = \int_{\mathcal{X}_{i_t}} \phi_t(\mathbf{x}_{i_t}, \mathbf{x}_{N_t}) d\mu_{i_t}(\mathbf{x}_{i_t})$$

对 μ_{N_t} 几乎处处 $\mathbf{x}_{N_t}$ 有限。此时对每个 $t = 0, \dots, k$ ，积分消元满足

$$P^{(t)}(\mathbf{x}_{(V \setminus O) \setminus I_t}) = \int_{\mathcal{X}_{I_t}} F_e(\mathbf{x}_{V \setminus O}) d\mu_{I_t}(\mathbf{x}_{I_t})$$

对 $\mu_{U \setminus I_t}$ 几乎处处成立。若要将 F_e 归一化为概率密度，还须有

$$0 < Z_e := \int_{\mathcal{X}_U} F_e(\mathbf{x}_U) d\mu_U(\mathbf{x}_U) < \infty.$$

对纯最大化消元，设各变量状态空间非空，并要求对每个 $t = 1, \dots, k$

及每个 $\mathbf{x}_{N_t} \in \mathcal{X}_{N_t}$,

$$\emptyset \neq \arg \max_{x_{i_t} \in \mathcal{X}_{i_t}} \phi_t(x_{i_t}, \mathbf{x}_{N_t}), \quad \tau_t^{\max}(\mathbf{x}_{N_t}) := \max_{x_{i_t} \in \mathcal{X}_{i_t}} \phi_t(x_{i_t}, \mathbf{x}_{N_t}) < \infty.$$

此时对每个 $t = 0, \dots, k$ 及每个剩余配置, 均有

$$P^{(t)}(\mathbf{x}_{(V \setminus O) \setminus I_t}) = \max_{x_{i_t} \in \mathcal{X}_{i_t}} F_{\mathbf{e}}(\mathbf{x}_{V \setminus O}).$$

证明. 初始 $t = 0$ 时没有消去变量, 当前乘积就是 $F_{\mathbf{e}}$, 等式成立。假设 $t-1$ 步后成立。把当前乘积分成桶外部分 ρ_t 与桶内部分 ϕ_t , 即 $P^{(t-1)} = \rho_t \phi_t$ 。因为收集了所有含有 X_{i_t} 的因子, ρ_t 与 x_{i_t} 无关。求和消元于是给出

$$\begin{aligned} P^{(t)} &= \rho_t \sum_{x_{i_t}} \phi_t \\ &= \sum_{x_{i_t}} P^{(t-1)} \\ &= \sum_{x_{i_t}} \sum_{\mathbf{x}_{I_{t-1}}} F_{\mathbf{e}} = \sum_{\mathbf{x}_{I_t}} F_{\mathbf{e}}. \end{aligned}$$

第一行正是算法执行的因子替换; 第二行使用分配律; 第三行代入归纳假设, 并合并有限求和。因此不变式对 t 也成立。

积分情形中, 与积分变量无关的有限乘数仍可提出积分号, 非负可测性允许按 Tonelli 定理合并迭代积分; 定理中的逐步有限性条件保证更新因子及所得等式在相应剩余变量的乘积测度下几乎处处取有限值。纯最大化情形中, 由于 $\rho_t \geq 0$, 有 $\rho_t \max_{x_{i_t}} \phi_t = \max_{x_{i_t}} (\rho_t \phi_t)$ 。将归纳假设代入, 再利用同类最大化可合并为联合最大化, 即得相应不变式。若某个桶外乘积为零, 两边均为零, 不要求严格正性。 ■

边缘查询在 $I_k = R$ 时终止, 不变式直接给出 $P^{(k)} = g_Q$, 再除以 $Z_{\mathbf{e}}$ 就得到式 (20.3)。MPE 消去全部 U 后, 不变式给出标量 $v^* = \max_{\mathbf{x}_U} F_{\mathbf{e}}$ 。要证明回溯恢复的配置也达到这个值, 需要利用保存的选择: 对已经确定的后续变量, $b_t(\mathbf{x}_{N_t}^*)$ 使局部乘积等于 $\tau_t(\mathbf{x}_{N_t}^*)$; 乘上桶外部分后, 消元前后的乘积在这个扩展配置上相等。从最终标量开始逆序重复此步骤, 就得到 $F_{\mathbf{e}}(\mathbf{x}_U^*) = v^*$ 。这证明了得分和配置两种输出, 而不只是证明算法能找到某个局部最大值。

混合求和与最大化时, 不能把不变式含混地写成“对已消元变量做聚合”而省略运算的嵌套顺序。对于先求和、后最大化的边缘 MAP, 在求和阶段仍有 $P^{(t)} = \sum_{x_{i_t}} F_{\mathbf{e}}$ 。全部 R 消去后, 令 $J_s \subseteq M$ 表示又消去了 s 个最

大化变量，则

$$P^{(|R|+s)} = \max_{\mathbf{x}_{J_s}} \sum_{\mathbf{x}_R} F_{\mathbf{e}}. \quad (20.20)$$

这是在求和阶段产物上继续应用纯最大化不变式。终止时 $J_s = M$ ，得到式 (20.18) 的最优得分；最大化阶段的逆序回溯给出达到它的目标配置。任意交错顺序保持的是实际执行的嵌套算子表达式，不保证该表达式仍等于原来的 MAP 目标。

上述证明讨论的是精确代数运算。实数加法在浮点表示下不严格结合，不同消元顺序可能累积不同舍入误差；连乘可能下溢，病态矩阵求解可能放大误差。离散表格的逐项穷尽和高斯的解析积分使算法在数学上精确，但不保证机器输出与实数答案逐位相同，也不保证近乎并列的最优配置在舍入后仍有相同次序。数值稳定性因此需要单独处理。

20.4.2 消元顺序与计算复杂度

不变式保证了合法顺序都能给出正确答案，却没有说每个顺序同样便宜。仍以报警后的 F, H, S 为例：按 S, H 消元，两个桶的作用域依次是 $\{S, H\}$ 与 $\{H, F\}$ ；若先消去 H ，就必须把 $p(h | f)$ 与 $\ell_A(h, s)$ 合并，生成关于 (f, s) 的因子。后一个顺序在第一步便访问了三元表，原始因子数量完全没有变化。决定主要开销的是桶中作用域的并集，而不只是因子的个数。

图 20.2 用同一张二元星形图把这种差异放大。叶节点只有一个邻居，先消去它们不会产生填充边；中心节点同时连接四个叶节点，若先消去中心，新因子就必须以全部四个叶节点为自变量。两种顺序给出相同的最终标量，却分别只需访问至多 4 项和首步 32 项的桶。

为了在真正计算数值前预测这种增长，可以将当前因子转成一张无向图：同一因子作用域中的节点两两相连，得到**原始交互图** (primal graph)，它记录哪些变量必须在同一个局部函数中共同出现。这里使用的是吸收证据后实际因子的作用域，而不是直接使用原有向图的骨架。一个条件概率因子会使其节点和父节点共同构成团；证据约简以后，再依据剩余作用域建图。

消去节点 i 时，设它在当前图中的邻居集合为 $N(i)$ 。桶的乘积涉及 $\{i\} \cup N(i)$ ，消去 i 后生成一个作用域为 $N(i)$ 的因子。因此要把 $N(i)$ 中的节点两两连通，再删除 i ；原来不存在而新增的边称为**填充边** (fill edge)。这些边记录算法产生的潜在共同依赖，不能一概当成统计依赖的证明，因为特殊参数可能使某些项抵消或允许进一步分解。保留全部填充边所形成的图称为该顺序的**诱导图** (induced graph)。

这里删除的是变量，不是它对邻居的影响。以报警查询为例，若先消去 H ，新因子 $\sum_h p(h | f) \ell_A(h, s)$ 仍同时依赖 f, s ，所以必须用填充边 $F - S$ 记录这项共同作用。一般地，中间因子以剩余邻居为边界，针对每组边界




图 20.2 同一因子图上的好、坏消元顺序。所有变量均为二元，原始交互图是五节点星形图。(a) 先消去叶节点时，每个桶最多只含叶与中心两个变量，不产生填充边；(b) 先消去中心时，四个剩余邻居被补成团，第一桶必须枚举五个变量的 $2^5 = 32$ 种配置。红色节点表示当前先消去的变量，红边表示由该步新增的填充边。这里比较的是稠密表格实现的结构代价，不是两种顺序的数值答案。

状态汇总已经归入当前桶的子问题；后续计算只需读这张表，不必重新展开被消去的内部变量。填充记录的是需要保存哪些坐标，因子表保存的才是各坐标下的完整数值贡献。

定义 20.3 诱导宽度与树宽 对无向交互图 $\mathcal{G}$ 的一条完整消元顺序 π ，令 N_t 为消去第 t 个节点之前、已经加入前面填充边后的剩余邻居集合。该顺序的**诱导宽度** (induced width) 是

$$w(\pi) = \max_t |N_t|.$$

图的**树宽** (treewidth) 定义为所有完整消元顺序中的最小诱导宽度：

$$\text{tw}(\mathcal{G}) = \min_{\pi} w(\pi).$$

宽度不包含本步被消去的节点，所以最大桶作用域的大小为 $w(\pi)+1$ 。

树宽衡量能否安排一条顺序，使每次只需让少量剩余变量共同参与计算。树或森林可以反复消去叶节点，只要至少有一条边，其树宽就是 1；完全图有 d 个节点，无论从何处开始，第一步都有 $d-1$ 个剩余邻居，所以树宽为 $d-1$ 。节点数很大但接近树状的模型可能容易消元；节点数较少但作用域高度重叠的模型也可能难以消元。

离散表格的代价可以精确地对应到作用域。令 $r_i = |D_i|$ ，并定义

$$D(A) = \prod_{i \in A} r_i, \quad D(\emptyset) = 1.$$

这个 $D(A)$ 是作用域 A 的状态组合数，不是节点集合。设第 t 桶含有 c_t 个因子，作用域并集为 $U_t = \{i_t\} \cup N_t$ 。按稠密表格直接对齐、相乘和聚合，需要 $O(c_t D(U_t))$ 次标量操作；结果因子有 $D(N_t)$ 项。若把乘积 ϕ_t 完整物化，还需要 $D(U_t)$ 项工作存储。若逐个枚举 $\mathbf{x}_{N_t}$ 并在 x_{i_t} 上累加或取最大值，可以不保存完整乘积，将本步新增表格存储降为 $D(N_t)$ 项，但输入因子和其他未处理因子仍须存放。

当所有基数至多为 r 、因子数 $m = O(d)$ ，且采用宽度为 w 的完整顺序时，总运算量的常用上界为

$$T = O(dr^{w+1}). \quad (20.21)$$

每个因子至多被某个桶消耗一次，而每次消元新增一个因子，因此全部桶所处理的因子出现次数为 $O(m + d)$ ；若不假设 $m = O(d)$ ，可将式中的 d 替换为 $m + d$ 。这里采用每次标量运算代价为常数的算术模型，未计入精确有理数运算可能增长的位数。峰值临时乘积大小为 $O(r^{w+1})$ ；新生成因子及 MPE 回溯表的总大小可上界为 $O(dr^w)$ ，实际同时存活的部分可能更少。报告总空间时还必须加上输入因子的存储，不能将“单个输出因子的大小”误写为整个算法的空间。

对于保留 Q 的边缘查询，诱导过程只执行到 R 消完。若还要求物化一张完整的查询表，最终输出需要 $D(Q)$ 项，即使剩余因子还能分解也不能省掉这笔输出代价。设消元阶段最大 $|N_t|$ 为 w_R ，为空时取 $w_R = 0$ ；令

$$\bar{w} = \max\{w_R, |Q| - 1, 0\}.$$

在上述基数条件下，消元加上最终表格乘积可用 $O((m + d)r^{\bar{w}+1})$ 上界，输出空间另有 $D(Q)$ 项。也可以在分析前把 Q 补成团，并将它们安排在顺序末尾，得到与显式联合输出相适应的宽度指标。普通树宽优化允许消去所有变量，而查询保留约束不允许提前消去 Q ，两者不是同一个优化问题。

选择顺序时，**最小度启发式** (min-degree) 在当前诱导图中优先消去剩余邻居最少的节点；**最小填充启发式** (min-fill) 则优先消去需要新增填充边最少的节点，即数一数其邻居之间还缺多少条边才能组成团。两者都必须在每步添加填充边之后重新评估，不能只根据原图度数排一次序。最小度直接控制当前桶的变量数量，最小填充试图限制后续图的变密，但两种局部选择都不保证全局最优。一般图上的最小树宽排序问题是 NP 难的，实践中因而常使用启发式排序，再根据估计的中间表格规模决定是否执行精确消元⁴。

⁴ D. Koller, N. Friedman, *Probabilistic Graphical Models: Principles and Techniques*, MIT Press, 2009

当变量基数差异较大, 单看邻居数量会误判。一个只含三个大基数变量的桶, 可能比含五个二元变量的桶大得多。**最小权重启发式** (min-weight) 的一种常用约定, 是优先消去使 $\prod_{j \in N(i)} r_j$ 最小的节点 i , 即比较新生成因子的表项数; 取对数后等价于比较 $\sum_{j \in N(i)} \log r_j$ 。

若按本步计算量比较候选节点 i , 可用 $\sum_{j \in \{i\} \cup N(i)} \log r_j$, 即候选桶状态数乘积的对数; 这里还包含被消去的变量, 区别于只比较后继因子的指标。另一种加权方式对新增边 (i, j) 按 $r_i r_j$ 计分, 衡量的是填充代价, 与前两种状态数指标不同。这些权重都是计算成本的代理量, 不是概率权重。MAP 排序还要在当前允许消去的变量中选择候选, 不能让一个低度目标变量提前越过未完成的求和阶段。

高斯因子虽然也会产生填充, 但没有 $r^{|U_i|}$ 张不同取值的表项。令一次块消元涉及 b 维被消去变量与 a 维保留变量。对齐并相加 c_t 个稠密规范形式因子, 保守代价为 $O(c_t(a+b)^2)$ 。实现式 (20.15) 时, 不显式构造逆矩阵: 对 $\mathbf{J}_{B,B}$ 做 Cholesky 分解需 $O(b^3)$, 求解 $\mathbf{J}_{B,B} \mathbf{W} = \mathbf{J}_{B,A}$ 需 $O(b^2 a)$, 形成 $\mathbf{J}_{A,B} \mathbf{W}$ 需 $O(a^2 b)$; 一次项和常数项的更新不超过这些主要量级。因此核心块消元的算术代价为

$$T_{\text{Gauss}} = O(b^3 + b^2 a + b a^2), \quad S_{\text{Gauss}} = O((a+b)^2). \quad (20.22)$$

若逐个消去标量变量, $b=1$, 每步对 a 个邻居做二次规模更新, 典型总消元代价为 $O(\sum_t (|N_t|+1)^2)$, 另加输入装配成本。对一个总维度为 q 的稠密高斯系统, 整体分解是 $O(q^3)$ 时间、 $O(q^2)$ 存储, 而不是对连续变量套用“无穷大状态数”的指数公式。块维度不等时, 应比较实际的 a, b , 不能只数图节点。

比较项	离散稠密表格	单个高斯规范形式
作用域的表达	每种联合状态一项	二次项矩阵、一次项向量、常数
合并因子	坐标对齐后逐项乘	坐标对齐后参数相加
边缘消元	对被消去状态求和	配方积分与 Schur 补
主要规模	基数乘积 $D(U_t)$	矩阵块维度 a, b
填充的后果	新表可能指数增大	更多非零块与矩阵运算

表 20.4 相同消元结构在两种因子表示下的不同代价。右列只适用于单个可归一化高斯核, 不涵盖消元时分量数量增长的高斯混合。

边缘 MAP 还需要一个区别于普通树宽的指标。令 $\Pi_{R \prec M}$ 为所有先排列 R 、后排列 M 的完整消元顺序, 其中各组内部顺序任意。定义这类查询的**受约束树宽** (constrained treewidth) 为

$$w_c(\mathcal{G}; R, M) = \min_{\pi \in \Pi_{R \prec M}} w(\pi). \quad (20.23)$$

给定合法顺序的 $w(\pi)$ 相应称为受约束诱导宽度。由于可选顺序减少, $w_c \geq \text{tw}(g)$ 。这里采用保证任意非负因子正确的两阶段顺序, 不把依赖特定数值的可交换性计入指标; 它刻画的是这类受约束表格消元的结构开销, 不是所有 MAP 算法的时间下界。

对选定的合法顺序, 式 (20.21) 中的 w 应取该顺序的诱导宽度。只有采用最佳合法顺序时, 才可将其换成 w_c , 得到 $O((m+d)r^{w_c+1})$ 的运算上界; 启发式找到的顺序可能更宽。这正是受约束树宽与离散表格复杂度的联系。

一个星形图即可说明差距可以任意大。设中心为 X_0 , 有 k 个叶节点 $X_1, \dots, X_k$, 联合分解为 $p(x_0) \prod_{j=1}^k p(x_j | x_0)$, 所有变量均为二元。纯求和或 MPE 可以依次消去叶节点, 每一步只有一个邻居, 故普通树宽为 1。若 MAP 目标恰为全部叶节点, 中心属于求和集合, 则两阶段算法必须先消去中心:

$$g(x_1, \dots, x_k) = \sum_{x_0} p(x_0) \prod_{j=1}^k p(x_j | x_0). \quad (20.24)$$

中心的全部 k 个邻居随之组成团, 受约束树宽为 k 。显式输出 g 需 2^k 项, 中心桶的联合枚举需访问 2^{k+1} 个状态组合, 即便原始输入只有 $O(k)$ 张常数大小的表。图 20.3 给出 $k=4$ 的情形。




图 20.3 边缘 MAP 引起的填充, 图中 $k=4$ 。左侧中心 X_0 要求和, 四个叶节点要共同最大化; 右侧消去中心后, 叶节点由虚线填充边连成团。若是 MPE, 则可以先消叶节点, 此时不产生这些填充边。

这不是说星形模型的每组数值都必须付出同样代价。例如某些因子可能使式 (20.24) 再次分解, 其他算法也可能利用特殊结构。但只依赖作用域、按稠密表格执行通用消元时, 普通树宽为 1 不足以给边缘 MAP 提供小开销保证。受约束宽度与普通宽度之间的差距, 是边缘 MAP 相对于纯边缘推断和 MPE 更难处理的一项具体原因⁵。

⁵J. D. Park, A. Darwiche, *Complexity Results and Approximation Strategies for MAP Explanations* In *Journal of Artificial Intelligence Research*, 2004, vol. 21, pp. 101–133

20.4.3 实现与适用边界

离散实现除了保存数值，还必须保存变量轴、状态编码和作用域。转置后再广播相乘，或采用带变量名的对齐操作，可以避免“表格形状相同但坐标含义不同”的静默错误。若因子由确定性约束产生，许多配置的权重为零，可只存储非零项；这种稀疏存储只有在消元后的因子仍稀疏时才有优势。求和可能让原来分散的支持集合合并，大量填充也会使中间因子变稠密，因此应在执行前估计峰值作用域，并在运行时监测实际非零项数量。

高斯实现通常利用**稀疏 Cholesky 分解** (sparse Cholesky factorization)，即把稀疏正定精度矩阵分解为三角因子，并只存储原有非零项及消元产生的填充项。图排序决定哪些位置会出现填充，数值阶段再计算这些位置的系数。多次处理同一稀疏结构时可以复用排序和符号分析；只有当矩阵数值也不变时，才能原样复用数值分解。式 (20.15) 中的逆记号服务于推导，程序中应使用三角方程求解，并由分解对角线计算 $\log |J_{B,B}|$ 。

概率连乘在模型稍大时就可能下溢。把非负因子转到**对数域** (log domain)，即存储 $\log \psi$ 而不是 ψ ，可将乘积变成加法；零权重用 $-\infty$ 表示。MPE 的局部更新变成“求和后取最大值”，回溯索引不变。边缘消元则不能把求和直接改为最大化，而要使用稳定的对数求和指数运算：

$$\log \sum_i \exp a_i = a_{\max} + \log \sum_i \exp(a_i - a_{\max}), \quad a_{\max} = \max_i a_i. \quad (20.25)$$

减去最大项避免指数上溢，使至少一个指数项为 1。若所有 $a_i = -\infty$ ，应直接返回 $-\infty$ ，不能计算 $-\infty - (-\infty)$ 。若最终所有查询状态的权重均为零，则应报告证据不相容，不应静默返回均匀分布。

中间归一化也是一种尺度控制，但只能除以不依赖该因子变量取值的正常数。若第 t 步将 τ_t 替换为 $\hat{\tau}_t = \tau_t / s_t$ ，其中 $s_t > 0$ ，并令 $C_t = \prod_{j=1}^t s_j$ ，则正确的不变式变成

$$C_t \prod_{\psi \in \hat{\mathcal{F}}^{(t)}} \psi = \text{原始函数按已执行顺序聚合后的结果}.$$

实现中记录 $\log C_t = \sum_{j=1}^t \log s_j$ 即可。最终计算条件分布时全局尺度抵消；计算证据权重或最优配置的绝对得分时则须补回。若被消元产生的是标量因子，也只能按这个规则处理，不能不加记录地忽略它。

退化高斯需要另外区分数学问题与数值问题。若完整精度矩阵只是半正定，并且仍把式 (20.13) 当作整个欧氏空间上的普通密度，它通常无法归一化；沿无二次约束的方向，积分会发散。若模型实际表示限制在低维仿射子空间上的退化高斯，则需要显式描述支持集并在相应子空间上积分，不能简单将逆换成伪逆、行列式换成伪行列式后继续使用同一个密度公式。若理论矩阵正定但数值上接近奇异，应检查条件数、尺度和分解残差。人

为加入对角扰动会改变模型，应说明扰动大小及其影响，不能将它称为完全等价的精确推断。

精确 VE 适合因子分解已知、查询明确、且中间作用域可控的情形。离散高树宽或大的受约束宽度会让表格消元超出内存；单个高斯模型没有同样的状态数指数增长，却也可能因巨大矩阵块和填充而承担高昂的多项式代价。若资源不足以维持全部相关信息，第 22 章和第 23 章将通过不同方式引入近似。

另一类开销来自重复查询。对同一个模型先问 F ，再问 S ，每次从头消元可能重复构造许多相同的中间因子。若证据和模型允许共享这些计算，可以把局部汇总结果缓存起来，让后续查询直接读取或组合。第 21 章的消息传递与团树方法正是围绕这种组织方式展开。它们能够复用计算，但不会仅凭缓存就消除由大作用域带来的困难。

20.5 本章小结

报警后的故障概率不要求先列出完整联合分布。把证据代入局部因子后，分配律允许逐个收集、相乘和边缘化非查询变量；当前因子乘积等于原始函数对已消去变量的聚合结果，这个不变式保证了终止时的答案。数值例子中的 $p(F = 1 \mid A = 1) \approx 0.384111$ 由全部可能解释共同贡献，而 MPE 给出的 $(F, H, S) = (0, 1, 0)$ 只是一组联合最优解释，二者承担不同任务。

查询语义决定消元算子，也决定哪些信息必须保留。边缘概率累加所有状态，不做最优配置回溯；MPE 采用纯最大化并保存局部选择，逆序恢复完整配置；边缘 MAP 先对非目标变量求和，再对目标变量最大化，这两类运算通常不可交换。由此产生的受约束树宽可能远大于普通树宽，即使原图是一棵树，也不保证通用边缘 MAP 表格消元便宜。

消元顺序决定中间作用域，因子表示决定该作用域的存储和运算代价。离散表格的大小是变量基数的乘积，因此受诱导宽度控制而指数增长；高斯规范形式则通过矩阵参数相加和 Schur 补完成解析消元，代价由实际块维度及填充模式决定。这些结构判断，加上归一化条件与数值稳定性检查，才构成选择精确推断方法的依据。中间因子可承受时，VE 提供直接且可验证的答案；多次查询需要进一步复用这些结果，而不可承受的大作用域则要求利用额外结构或接受明确的近似。

基于团树传播的精确推断

设备报警以后，诊断程序可能接连询问故障概率、过热概率，以及故障与传感器失灵的联合概率。第 20 章的变量消除可以分别回答这些问题，但若每次都从原始因子开始，许多局部求和会重复进行。问题不在于这些求和算错了，而在于一次查询产生的中间结果没有被组织成后续查询可以继续使用的形式。

本章把中间因子保存为**消息** (message)：一张只保留边界变量、汇总边界一侧全部贡献的函数表。树结构使这种汇总特别直接，因为删除一条边就能把计算分成两部分。一般图没有这样的边界划分，需要先把相互依赖的变量组合成团，再用满足特定交集条件的树连接这些团。构造是否保留了正确边界、传播是否汇总了完整贡献、查询是否正确使用缓存，是精确性的三个不同问题。

除特别说明外，本章讨论有限离散变量，因子非负且取有限值。记变量节点集合为 V ， X_i 的状态集合为 $\mathcal{X}_i$ ， $\mathbf{x}_A$ 表示 $A \subseteq V$ 上各变量的一组取值。模型参数在推断期间固定，不在消息传播中重新估计。以下求和都是对所标变量的全部状态求和，空乘积约定为 1。

21.1 从变量消除到消息传递

沿用设备故障模型，以二元变量 F, H, A, S 分别表示故障、过热、报警和传感器失灵，其联合分布为

$$p(f, h, a, s) = p(f)p(h | f)p(s)p(a | h, s). \quad (21.1)$$

这里 $p(F = 1) = 0.1$ 、 $p(S = 1) = 0.05$ ，且 $p(H = 1 | F = 0) = 0.1$ 、 $p(H = 1 | F = 1) = 0.8$ 。报警条件表见表 21.1，其余二元概率用 1 减去表中对值求得。这些参数是人工教学设置，不是设备实测统计。

观察 $A = 1$ 后，为查询 F 而消去 S ，得到

$$u(h) = \sum_s p(s)p(A = 1 | h, s), \quad (u(0), u(1)) = (0.0445, 0.9045). \quad (21.2)$$

h	s	$p(A = 1 h, s)$
0	0	0.01
1	0	0.90
0	1	0.70
1	1	0.99

表 21.1 贯穿本章的报警条件概率。 $S = 1$ 表示传感器失灵，既可能在不过热时触发报警，也可能与过热同时出现。

这个中间因子并非只对查询 F 有用。只要模型参数和报警证据不变， $u(h)$ 就始终概括传感器与报警对 H 的贡献；计算过热后验时可以直接复用它。另一方面，从故障侧消去 F 得到

$$v(h) = \sum_f p(f)p(h | f), \quad (v(0), v(1)) = (0.83, 0.17). \quad (21.3)$$

这张表不依赖报警证据。两侧结果相乘，便有 $p(h, A = 1) = u(h)v(h)$ 。一次局部消元因此可以服务于多个查询，也可以在另一侧证据改变以后继续使用。

普通的单次变量消除常在中间因子完成用途后将其丢弃；变量消除本身并不禁止缓存。消息传递进一步规定缓存的作用域、依赖方向和更新规则，使程序知道哪些结果可以共享。图 21.1 中的因子图是一棵树，切断 H 与报警因子之间的边后，左右两侧只通过 H 的取值联系。固定 h ，各侧可以独立消去内部变量，再把结果相乘。消息就是这种以边界取值为输入的局部计算结果，而不是一个节点向另一个节点传送的单个概率。




图 21.1 报警模型的树状因子图。圆表示变量，方框表示因子； $A = 1$ 作为变量处的证据。虚线切断 H 与 f_A 之间的边，蓝色与黄色箭头分别表示两侧汇总得到的 $v(h)$ 和 $u(h)$ ，不是原有向图的因果箭头。

这种计算也属于动态规划：对子问题按边界状态制表，较大的子问题只读取相邻子问题的结果。树保证每一侧的贡献有明确归属。若直接在有环图上传播，同一个因子可能沿不同路径回到原处；此时上述互不重叠的子

问题解释不再自动成立。

21.2 树结构上的消息传递

把局部汇总写成统一公式，需要分清变量节点和因子节点的职责。设因子索引集为 $\mathcal{F}$ ， f_α 的作用域为 $D_\alpha \subseteq V$ 。每个变量至少属于一个因子；没有实际约束的变量可以添加一个恒为 1 的一元因子。用 $\ell_i(x_i)$ 记录变量处的证据，未观测时取 1，观测 $X_i = e_i$ 时取指示函数 $\mathbf{1}\{x_i = e_i\}$ 。将全部证据记为 $\mathbf{e}$ ，定义

$$\begin{aligned} q_{\mathbf{e}}(\mathbf{x}) &= \prod_{\alpha \in \mathcal{F}} f_\alpha(\mathbf{x}_{D_\alpha}) \prod_{i \in V} \ell_i(x_i), \\ Z_{\mathbf{e}} &= \sum_{\mathbf{x}} q_{\mathbf{e}}(\mathbf{x}), \quad p(\mathbf{x} | \mathbf{e}) = \frac{q_{\mathbf{e}}(\mathbf{x})}{Z_{\mathbf{e}}}. \end{aligned} \quad (21.4)$$

条件分布要求 $Z_{\mathbf{e}} > 0$ 。这里保留了被观测变量，其后验质量集中在观测值上，便于在证据更新时沿用同一张图。若原模型未归一化，其无证据配分函数记为 Z_0 ，硬证据的概率为 $Z_{\mathbf{e}}/Z_0$ ，不能直接把 $Z_{\mathbf{e}}$ 称为证据概率。

21.2.1 和积消息

设因子图连通且无环， $N(i)$ 为变量 i 的相邻因子集合， $N(\alpha) = D_\alpha$ 为因子 α 的相邻变量集合。**和积消息** (sum-product message) 用乘法汇合不同分支，再用求和消去不需要传出的变量。变量到因子、因子到变量分别有

$$m_{i \rightarrow \alpha}(x_i) = \ell_i(x_i) \prod_{\beta \in N(i) \setminus \{\alpha\}} m_{\beta \rightarrow i}(x_i), \quad (21.5)$$

$$m_{\alpha \rightarrow i}(x_i) = \sum_{\mathbf{x}_{D_\alpha \setminus \{i\}}} f_\alpha(\mathbf{x}_{D_\alpha}) \prod_{j \in D_\alpha \setminus \{i\}} m_{j \rightarrow \alpha}(x_j). \quad (21.6)$$

变量节点只代表同一个 x_i ，所以它将自身证据与其他分支的贡献逐项相乘，不消去 x_i 。因子节点连接多个变量；固定接收方的 x_i 以后，它将其他变量的状态逐一加总，输出仍是一张关于 x_i 的表。

为什么乘积必须排除接收方？切断边 (i, α) 后， $m_{i \rightarrow \alpha}$ 只应包含 i 所在一侧的因子；来自 α 的消息已经汇总了另一侧。若将它乘回去，另一侧的贡献就会被重复计入。对于式 (21.6)，删除 α 后，各邻接变量所在分支互不相交。固定这些邻接变量，分支内部求和可以分别进行，再由分配律提到 f_α 旁边。这就推导出局部更新式，而不是仅凭图形猜测一个递推关系。

在报警例中，令 $f_F = p(f)$ 、 $f_H = p(h | f)$ 、 $f_S = p(s)$ 、 $f_A = p(a | h, s)$ 。叶侧先得到 $m_{F \rightarrow f_H}(f) = p(f)$ 与 $m_{S \rightarrow f_A}(s) = p(s)$ ，观测变量发送

$m_{A \rightarrow f_A}(a) = \mathbf{1}\{a = 1\}$ 。于是

$$m_{f_H \rightarrow H}(h) = \sum_f p(h | f)p(f) = v(h),$$

$$m_{f_A \rightarrow H}(h) = \sum_{a,s} p(a | h, s)\mathbf{1}\{a = 1\}p(s) = u(h).$$

因 H 没有自身证据, $m_{H \rightarrow f_A} = v$ 、 $m_{H \rightarrow f_H} = u$ 。从两个方向读取同一条边上的消息, 读到的是两侧不同的贡献, 并非同一条件概率的两种写法。因子图上的这种局部和积规则统一了树上多种动态规划算法¹。

21.2.2 消息调度与边缘恢复

消息公式还规定了计算顺序: 节点向某个邻居发送消息之前, 需要收到所有其他邻居的消息。任选一个变量节点作为根, 按从叶到根的顺序执行**收集**(collect), 即把各分支贡献汇总到根。叶变量只发送 ℓ_i , 叶因子只发送自己的一元函数。根得到全部入站消息后, 再沿从根到叶的顺序执行**分发**(distribute), 把各节点尚缺少的另一侧贡献传下去。

若因子图有 M 条边, 完整传播发送 $2M$ 条有向消息, 每个方向恰好一次。树上不存在需要反复迭代等待收敛的问题: 收集阶段的依赖按深度递减, 分发阶段的依赖按深度递增, 都有确定的终止顺序。如果只查询根的边缘, 收集已经足够; 分发的收益是让其余节点也拥有完整的入站信息。

传播完成后, 定义未归一化的局部汇总

$$B_i(x_i) = \ell_i(x_i) \prod_{\alpha \in N(i)} m_{\alpha \rightarrow i}(x_i),$$

$$B_\alpha(\mathbf{x}_{D_\alpha}) = f_\alpha(\mathbf{x}_{D_\alpha}) \prod_{j \in D_\alpha} m_{j \rightarrow \alpha}(x_j).$$
(21.7)

以 i 或 α 为中心切开树, 所有分支恰好覆盖全图的其余因子, 故 $B_i = \sum_{\mathbf{x}_{V \setminus \{i\}}} q_{\mathbf{e}}$, $B_\alpha = \sum_{\mathbf{x}_{V \setminus D_\alpha}} q_{\mathbf{e}}$ 。两者分别除以 $Z_{\mathbf{e}}$ 就是相应后验边缘。若变量 i, j 同属 D_α , 对 B_α 中的其他变量求和便能得到 $p(x_i, x_j | \mathbf{e})$ 。对成对因子图, 这正是原模型一条边两端变量的联合边缘; 因子图自身是二部图, 不存在变量节点直接相连的边。

报警例的 H 处给出

$$(B_H(0), B_H(1)) = (0.036935, 0.153765), \quad Z_{\mathbf{e}} = 0.19070. \quad (21.8)$$

因此 $p(H = 1 | A = 1) \approx 0.806319$ 。继续向故障侧分发, $m_{f_H \rightarrow F}(f) = \sum_h p(h | f)u(h)$, 得到 $(0.1305, 0.7325)$; 乘 $p(f)$ 以后便恢复 $p(F = 1 | A = 1) = 0.07325/0.19070 \approx 0.384111$ 。

以上等式保留了消息的原始尺度。实际计算中可将一条非零消息整体

¹ F. R. Kschischang, B. J. Frey, H.-A. Loeliger, *Factor Graphs and the Sum-Product Algorithm* In IEEE Transactions on Information Theory, 2001, vol. 47, no. 2, pp. 498–519

除以正数，避免很小的权重连乘导致下溢；局部结果再归一化后仍给出相同边缘。但是，经过独立缩放的 B_i 之和不再自动等于 Z_e 。若需要证据概率，必须同步保存缩放常数并恢复尺度。全零消息不能归一化；它表明该侧所有边界状态都无法与证据相容，需要继续报告零证据权重，而不是任意填入均匀分布。

21.2.3 最大积消息

若目标从“各状态共有多少概率质量”改为“哪一组完整状态权重最大”，求和必须改成最大化。**最大积消息**（max-product message）保存边界给定时一侧子树能够达到的最大权重。以 ν 区别于和积消息，其更新为

$$\begin{aligned} \nu_{i \rightarrow \alpha}(x_i) &= \ell_i(x_i) \prod_{\beta \in N(i) \setminus \{\alpha\}} \nu_{\beta \rightarrow i}(x_i), \\ \nu_{\alpha \rightarrow i}(x_i) &= \max_{\mathbf{x}_{D_\alpha \setminus \{i\}}} f_\alpha(\mathbf{x}_{D_\alpha}) \prod_{j \in D_\alpha \setminus \{i\}} \nu_{j \rightarrow \alpha}(x_j). \end{aligned} \quad (21.9)$$

因子非负，才可以在不同分支间使用 $\max_{\mathbf{y}, \mathbf{z}} g(\mathbf{y})h(\mathbf{z}) = (\max_{\mathbf{y}} g)(\max_{\mathbf{z}} h)$ 。消息只记录最大值还不够；计算 $\nu_{\alpha \rightarrow i}(x_i)$ 时，还应为每个 x_i 存储一组达到最大值的 $\mathbf{x}_{D_\alpha \setminus \{i\}}$ ，称为**回溯记录**（backpointer），即根据边界状态找回子问题最优选择的表。

完整的入站最大积消息相乘得到 $\hat{B}_i(x_i) = \ell_i(x_i) \prod_{\alpha \in N(i)} \nu_{\alpha \rightarrow i}(x_i)$ ，它是固定 x_i 以后全图能够达到的最大权重，称为**最大边缘**（max-marginal）。它保留的是每个 x_i 下最优配置的权重，而概率边缘累加所有配置的权重，二者不能互相替代。

收集结束后，在根处最大化自身证据与全部入站消息的乘积，确定根状态。随后逐层读取回溯记录：已知父变量状态，就确定相邻因子另一侧各变量的状态，再向更深的分支继续。若最优选择不唯一，可以按固定顺序保存其中一组，但必须沿同一套条件选择回溯。不能让每个变量独立取其最大边缘状态，因为不同位置的任意平局选择可能拼不成一组相容解。例如两个二元变量只有 (0,0)、(1,1) 权重为 1，其余权重为零，则两个位置的最大边缘都对 0,1 平局；各自任意选择可能拼出权重为零的 (0,1)。

以 H 为根，故障侧的最大积汇总为

$$\begin{aligned} \nu_{f_H \rightarrow H}(0) &= \max(0.9 \times 0.9, 0.1 \times 0.2) = 0.81, \\ \nu_{f_H \rightarrow H}(1) &= \max(0.9 \times 0.1, 0.1 \times 0.8) = 0.09. \end{aligned}$$

两种 h 都记录 $f = 0$ 。报警侧在 $h = 0$ 时比较 0.95×0.01 与 0.05×0.70 ，得 0.035 并记录 $s = 1$ ；在 $h = 1$ 时比较 0.95×0.90 与 0.05×0.99 ，得 0.855 并记录 $s = 0$ 。根处比较 $0.81 \times 0.035 = 0.02835$ 与 $0.09 \times 0.855 = 0.07695$ ，选 $h = 1$ 。回溯得到全部非证据变量的 MPE 为 $(f, h, s) = (0, 1, 0)$ ，未归一化

权重为 0.07695。这里的最大积消息与式 (21.3)、式 (21.2) 的和积消息数值不同，不能混用。

当树退化为隐状态链时，设隐状态为 Z_t ，观测为 $X_t = x_t$ ，最大积收集变成

$$\delta_t(z_t) = p(x_t | z_t) \max_{z_{t-1}} \{\delta_{t-1}(z_{t-1}) p(z_t | z_{t-1})\}.$$

以 $\delta_1(z_1) = p(z_1)p(x_1 | z_1)$ 初始化，保存每个 z_t 对应的最优前驱，再从末端回溯，就是 Viterbi 动态规划。第 28.2 节将把它用于离散时序模型。这里求的是全部隐状态的联合最优解；只对一部分变量求最优、对其余变量求和的边缘 MAP 仍受第 20.3.2 节的运算顺序约束。

21.3 团树的构造

树状因子图允许沿单变量边界汇总，一般因子图却可能含环。要保持精确性，可以让一条消息同时保留多个边界变量，将环内必须共同处理的变量放进同一个计算节点。**团树** (junction tree) 就是这样一棵以变量团为节点的树：节点是变量集合而不是原图中的单个变量，边表示相邻团的交集而不是原变量图中的边。相邻团可以重叠，但重叠方式必须保证每个变量的信息沿树连续传递。

图 21.2 先给出从含环原图到可复用消息的完整路线。原图指出哪些变量直接共同进入局部因子，却不能沿一条边切成互不重叠的子问题；消元与填充把新产生的依赖记录为弦，避免后续消元遗漏共同作用域；极大团把必须共同处理的变量收进局部计算节点；团树再以团交集作为两侧共享的边界；分配团势并沿每条树边发送两个方向的消息以后，两侧消元结果便能被后续查询复用。图中的每一步都改变计算组织方式，但不额外乘入因子，也不改变原分布。

21.3.1 从原图到弦图

团应当容纳原始因子的整个作用域。对于有向图，条件因子 $p(x_i | \mathbf{x}_{\text{pa}(i)})$ 同时涉及节点 i 及其全部父节点，因此先连接共同子节点的父节点，再去掉箭头，得到道德图。这里使用的是承载全部因子的整体道德图，不是为了检验某一次条件独立查询而取出的祖先子图。报警模型由此增加 $H - S$ 边，得到团 $\{F, H\}$ 和 $\{H, A, S\}$ 。

对于无向模型，因子作用域本来就应包含在团中；若输入是因子图，则将每个作用域内的变量两两相连，得到相应的变量交互图。接下来按一个选定的消元顺序操作：消去节点时，把它尚未消去的邻居全部连接起来，再移除该节点。将过程中新增的填充边保留在原节点集合上，就得到**三角化** (triangulation)，也称弦化；结果是一张每个长度至少为 4 的环都有弦的图。




图 21.2 团树编译与传播总览。四个面板按两行两列展开：四环先通过填充边 1-3 变为弦图，再提取极大团 $C_1 = \{1, 2, 3\}$ 与 $C_2 = \{1, 3, 4\}$ ；金色分隔集 $S_{1,2} = \{1, 3\}$ 明确标出两团共享状态，最后用双向消息汇总树边两侧的贡献。团树的节点和边属于计算结构，不是把原变量图改画成树。

选顺序时，可沿用第 20.4.2 节的最小度与最小填充启发式：前者少留邻居，后者少添邻居之间缺失的边。填充并不近似掉被消变量的作用，而是把这种作用转存到邻居的共同因子上。每步都保留这个边界子问题的完整汇总，后续才有足够信息继续消元；顺序不同改变的是表格大小，不是合法精确计算的答案。

为什么这个构造产生弦图？在所得图上，所选顺序中每个节点的后继邻居已经两两相连，因而它是完美消除序。若还有一个无弦长环，取环上最早被消去的节点，它在环上的两个邻居都尚未消去，必已相连；这条边恰好是该长环的一条弦，与无弦假设矛盾。第 19 章讨论过图转换的表示含义，这里新增边的计算作用是记录消元以后需要共同保留的变量，而不是新增一个概率因子或改变原来的参数。

图 21.2 中的四环 $1-2-3-4-1$ 也说明消元选择如何决定团的大小。先消去 2，需要添加 $1-3$ ，得到两个极大团 $\{1, 2, 3\}$ 和 $\{1, 3, 4\}$ ；先消去 1 则添加 $2-4$ ，得到 $\{1, 2, 4\}$ 和 $\{2, 3, 4\}$ 。两者都能承载同一个原始四环分布，但保存的消息分别定义在 $\{1, 3\}$ 和 $\{2, 4\}$ 上；变量状态数不同时，这两张表的成本可能相差很大。

21.3.2 极大团、分隔集与运行交集性质

一个团内部的节点两两相连；**极大团** (maximal clique) 是不能再加入其他节点而仍保持团性质的团。“极大”指不能扩充，不是全图中节点数最多。设极大团集合为 $\mathcal{C}$ ，以它们为节点构造树 $\mathcal{T} = (\mathcal{C}, \mathcal{E}_{\mathcal{T}})$ 。边 (C, D) 对应的**分隔集** (separator) 为 $S_{C,D} = C \cap D$ ，它是消息在两个团之间保留的变量集合。

先看图 21.3 中的三个团 $\{1, 2\}$ 、 $\{2, 3\}$ 和 $\{3, 4\}$ 。按这个顺序连成链时，含 2 的两个团相邻，含 3 的两个团也相邻，1, 4 则各只出现一次。若把 $\{3, 4\}$ 放在中间，含 2 的两端之间就隔着一个不含 2 的团。两种连接都是树，但后一种连接无法沿路径保留同一个 x_2 。

因此，仅让团连成树还不够。如果变量 i 出现在两个团中，它在两团之间的每一步传递都必须被保留。否则，中间某条消息会提前消去 i ，而路径另一端又要求按同一个 i 的状态组合因子，已经丢掉的信息无法恢复。

定义 21.1 运行交集性质 团树满足**运行交集性质** (running intersection property)，是指对任意变量 i ，包含 i 的全部团构成连通子树。等价地，对任意两个团 C, D ，从 C 到 D 的唯一路径上的每个团都包含 $C \cap D$ 。

两种表述的等价性来自树的唯一路径：若包含 i 的团连通，连接任意两个这样的团的路径只能位于该连通子树内；反之，若所有这些路径都保留 i ，这些团便相互连通。




图 21.3 运行交集检查的是变量是否沿团间路径连续出现。上排 $\{1, 2\}-\{2, 3\}-\{3, 4\}$ 满足要求；下排将 $\{3, 4\}$ 放在中间，连接两个含 2 的团时经过了不含 2 的团，即使图形无环也不合法。

这个条件可以化为后续证明需要的分隔结论。删除团树边 (C, D) ，令

$\mathcal{C}_{C|D}$ 为 C 侧的团集合, 并记 $U_{C|D} = \bigcup_{K \in \mathcal{C}_{C|D}} K$ 。则

$$U_{C|D} \cap U_{D|C} = S_{C,D}. \quad (21.10)$$

包含关系 “ $\supseteq$ ” 直接来自 C, D 分处两侧。反过来, 若 i 出现在两侧各一个团中, 连接这两个团的路径必经过边 (C, D) ; 运行交集要求 i 同时属于 C, D , 故 $i \in S_{C,D}$ 。这证明两侧共享的变量恰好就是消息所保留的分隔集, 不会有另一个共享变量被悄悄消去。

这就允许按分隔集状态做动态规划: 固定边界后, 两侧各自汇总内部变量, 再组合结果。精确性来自分配律和正确的分隔, 并非 “树宽有限就能高效计算”。有限图的树宽本来就有限; 离散稠密表格的成本仍指数依赖所选顺序的诱导宽度, 只有团的状态空间可承受时, 这种动态规划才实际可行。

运行交集失效时会发生实际数值错误。例如给二元链上的三个团分别分配 $\mathbf{1}\{x_1 = x_2\}$ 、 $\mathbf{1}\{x_2 = x_3\}$ 和 $\mathbf{1}\{x_3 = x_4\}$ 。全局只有全 0、全 1 两组非零配置, 权重和应为 2。若按图中错误顺序连接, 以 $\{1, 2\}$ 为根, $\{2, 3\}$ 先向 $\{3, 4\}$ 发送常数 1; $\{3, 4\}$ 再向根发送空分隔集上的标量 2。根求和得到 $2 \times 2 = 4$, 把两侧本应相同的 x_2 当成了两份可分别求和的变量。树形与局部消息公式都没有错, 错在树没有保留原问题要求的共享状态。

21.3.3 团树构造与因子分配

如何从弦图的团中选择正确连接, 而不逐棵树尝试运行交集? 构造**团交图** (clique intersection graph), 即将每个极大团作为节点, 以交集大小

$$w(C, D) = |C \cap D|$$

作为边权。通常只保留非空交集的边; 若原图不连通, 可以允许权为 0 的边把各分量连接起来, 消息在空分隔集上就是标量。为统一表述, 下面把这些零权边也视为候选边。

定理 21.2 最大权生成树与团树 设 $\mathcal{H} = (V, E)$ 为非空有限弦图, $\mathcal{C}$ 为其全部极大团。在以 $\mathcal{C}$ 为节点集合的完全无向图上, 对不同团 C, D 定义边权 $w(C, D) = |C \cap D|$, 其中不相交团之间的边权为 0。该完全图的一棵生成树满足运行交集性质, 当且仅当它是最大权生成树。

证明. 先说明满足运行交集的树确实存在。取弦图的完美消除序 $v_1, \dots, v_d$, 令 N_i^+ 为 v_i 的后继邻居, 建立集合 $K_i = \{v_i\} \cup N_i^+$ 。若 N_i^+ 非空, 取其中序号最小的 v_j , 把 K_i 连向 K_j 。由于 N_i^+ 是团, $N_i^+ \subseteq K_j$ 。连接方向的序号严格增加, 所以没有环; 没有后继邻居的节点成为各分量的根。

若某个 K_i 含 v_k 且 $i < k$, 其父集合仍含 v_k , 父序号又不大于 k 。不断向父集合移动, 最终到达 K_k 。因此包含 v_k 的集合都连向 K_k , 形成连通子树。每个图上的团都包含在某个 K_i 中: 取该团最早的节点, 其余节点都是它的后继邻居。于是极大团恰好是这些集合中的极大者。对非极大的 K_i , 选择一个包含它的极大集合; 连接两者的路径上的每个集合都包含 K_i , 所以可以把 K_i 收缩到路径上的相邻超集中。收缩不破坏任何变量的连通性。重复此操作得到以极大团为节点的树或森林; 不同分量之间用空交集连接即可。

再证明最大权判据。令 k_i 为包含变量 i 的极大团数, $e_i(\mathcal{T})$ 为候选树中两端都含 i 的边数。这些边构成 k_i 个节点上的森林, 故 $e_i(\mathcal{T}) \leq k_i - 1$, 等号当且仅当该森林连通。交换求和顺序得到

$$\sum_{(C,D) \in \mathcal{E}_{\mathcal{T}}} |C \cap D| = \sum_{i \in V} e_i(\mathcal{T}) \leq \sum_{i \in V} (k_i - 1).$$

已构造出的运行交集树对每个 i 都达到等号, 所以上界可以达到。任何最大权树也必须对每个 i 达到等号, 否则总权重严格小于该上界; 这恰好要求所有含 i 的团连通。反方向同理。 ■

实际构造时, 可以使用最大权版本的 Kruskal 算法。起初不选任何边, 将候选边按交集大小从大到小检查, 权重相同时按预定顺序处理。只有当两端的团尚未被已选边连通时, 才加入当前边; 否则加入它会形成环, 应当跳过。直到全部团连通, 共选出 $|\mathcal{C}| - 1$ 条边, 就得到最大权生成树。

复用图 21.3 中的三个团 $\{1, 2\}$ 、 $\{2, 3\}$ 和 $\{3, 4\}$, 前两个团的交集为 $\{2\}$, 后两个团的交集为 $\{3\}$, 首尾两团的交集为空。三条候选边的权重分别为 1, 1, 0。两条权为 1 的边依次连接尚未连通的团, 加入后即得到图中上排的链; 再加入零权边就会成环, 因此不选。

弦图的前提不能省略: 例如四环的四个边团无法组成运行交集树, 取最大权生成树也不能凭空补足缺失的变量。证明还说明, 最大化交集大小的用途是保证变量连通, 而不是寻找树宽最小的三角化; 三角化已经在构造团交图之前选定。关于分解图、团树及局部计算的系统论述可参见图模型教材²。

树确定后, 为每个原始因子 f_α 选择且只选择一个覆盖其作用域的团 $a(\alpha)$, 满足 $D_\alpha \subseteq a(\alpha)$ 。由此定义无证据团势

$$\phi_C^0(\mathbf{x}_C) = \prod_{\alpha: a(\alpha)=C} f_\alpha(\mathbf{x}_{D_\alpha}), \quad \prod_{C \in \mathcal{C}} \phi_C^0 = \prod_{\alpha \in \mathcal{F}} f_\alpha. \quad (21.11)$$

没有分到因子的团取恒等势 1。“能够覆盖”不等于“每个覆盖团都放一份”: 若把同一因子复制到两个团, 它在乘积中就被平方, 模型随之改变。报警例可以取 $C_1 = \{F, H\}$ 、 $C_2 = \{H, A, S\}$, 令 $\phi_{C_1}^0 = p(f)p(h | f)$ 、

²S. L. Lauritzen, *Graphical Models*, Clarendon Press, 1996

$\phi_{C_2}^0 = p(s)p(a | h, s)$, 分隔集为 $\{H\}$ 。

不同合法因子分配、不同最大权树和不同三角化都可能保持同一联合分布。它们改变局部表格、消息路由和可复用范围, 而不是改变概率答案。团很大但树形简单, 仍可能难以计算; 这一成本要根据实际状态空间评估。

21.4 团树传播

团树构造解决了共享变量怎样保留的问题。数值传播则将树上的单变量消息扩展为分隔集上的多变量消息。本节采用显式保存双向消息的形式, 发送时不需要除以旧消息, 因而允许原始因子或证据产生零表项。

21.4.1 团势与团间消息

团势 (clique potential) 是附在团上的非负函数, 用来存储该团负责的原始因子和证据。它不必归一化, 也不等于该团的边缘分布。为每个证据因子 ℓ_i 选择一个包含 i 的团 $h(i)$, 令

$$\phi_C(\mathbf{x}_C) = \phi_C^0(\mathbf{x}_C) \prod_{i: h(i)=C} \ell_i(x_i). \quad (21.12)$$

于是 $\prod_C \phi_C = q_{\theta}$ 。也可以吸收作用于多个变量的似然函数, 但必须由某个团完整覆盖它的作用域, 并明确该函数代表什么观测机制。每条证据信息只分配一次; 重复乘入一般软证据会重复计数, 而不只是改变记录方式。

记 $N_T(C)$ 为团 C 的邻居集合。图 21.4 把一条消息拆成可见的输入、消元和输出: 发送 $C \rightarrow D$ 时, 先将团势 ϕ_C 与除 D 外全部邻居的入站消息相乘, 再消去只属于发送团的变量 $C \setminus S_{C,D}$, 输出表只保留分隔集 $S_{C,D}$ 中的变量。反向消息执行同一操作, 但汇总的是 D 侧贡献; 两个方向都完成后, 相邻团才能在共享变量上校准。




图 21.4 团间消息的组成与双向校准。蓝色箭头是 C 收到的入站消息, 团势与这些消息相乘后, 对 $C \setminus S_{C,D} = \{1\}$ 中的 x_1 求和, 得到定义在分隔集 $\{2, 3\}$ 上的 $m_{C \rightarrow D}$; 发送时排除接收方 D 的入站消息。黄色双向箭头分别汇总树边两侧的贡献, 收集与分发都完成后, 两个团消去非共享变量所得的表均等于分隔集势 $B_{C,D}$ 。

将图中的操作写成公式，有

$$m_{C \rightarrow D}(\mathbf{x}_{S_{C,D}}) = \sum_{\mathbf{x}_{C \setminus S_{C,D}}} \phi_C(\mathbf{x}_C) \prod_{K \in N_{\mathcal{T}}(C) \setminus \{D\}} m_{K \rightarrow C}(\mathbf{x}_{S_{K,C}}). \quad (21.13)$$

各函数按相同变量的取值对齐，较小作用域的函数在其余坐标上重复使用。发送消息不修改 ϕ_C ；否则下一次发送时可能把已包含在入站消息中的贡献再次乘入。

为了区分局部输入与全局汇总，定义

$$\begin{aligned} B_C(\mathbf{x}_C) &= \phi_C(\mathbf{x}_C) \prod_{K \in N_{\mathcal{T}}(C)} m_{K \rightarrow C}(\mathbf{x}_{S_{K,C}}), \\ B_{C,D}(\mathbf{x}_{S_{C,D}}) &= m_{C \rightarrow D}(\mathbf{x}_{S_{C,D}}) m_{D \rightarrow C}(\mathbf{x}_{S_{C,D}}). \end{aligned} \quad (21.14)$$

B_C 称为团的汇总势； $B_{C,D}$ 是本章采用的**分隔集势**（separator potential），汇合边两侧对分隔集的贡献。它由两条消息计算，不是另一个需要乘入原模型的因子。不同边即使具有相同的变量交集，也分别保存自己的双向消息和分隔集势。

在报警例中，把 $\ell_A(a) = \mathbf{1}\{a = 1\}$ 放在 C_2 ，两个团势为

$$\begin{aligned} \phi_{C_1}(f, h) &= p(f)p(h | f), \\ \phi_{C_2}(h, a, s) &= p(s)p(a | h, s)\ell_A(a). \end{aligned}$$

两团都是叶端，所以没有额外入站消息：

$$\begin{aligned} m_{C_1 \rightarrow C_2}(h) &= \sum_f p(f)p(h | f) = v(h), \\ m_{C_2 \rightarrow C_1}(h) &= \sum_{a,s} p(s)p(a | h, s)\ell_A(a) = u(h). \end{aligned} \quad (21.15)$$

它们与树状因子图中的两侧汇总完全相同。更大的团树只是把原来数步消元合并为一次团间消息，不会引入新的概率运算。

21.4.2 收集、分发与校准

以团 R 为根，叶团向父团收集消息；一个非叶团收到所有子团消息后，再发送自己的父向消息。根拥有全部入站消息时，开始向每个子团分发。算法 21.1 给出完整调度。消息尚未计算不能与“恒为 1”混为一谈；只有公式中的空乘积才自然等于 1。

算法 21.1 团树上的和积校准

输入： 满足运行交集的团树、局部势 $\{\phi_C\}$ 、根 R
输出： 全部双向消息、汇总势 $\{B_C, B_{C,D}\}$ 和 Z_e

- 1: 将树定根, 记录每个非根团的父团
- 2: **for** 按后序遍历访问的非根团 C **do**
- 3: 按式 (21.13) 发送 C 到父团的消息
- 4: **end for**
- 5: **for** 按先序遍历访问的团 C **do**
- 6: **for** C 的每个子团 D **do**
- 7: 按式 (21.13) 发送 $C \rightarrow D$
- 8: **end for**
- 9: **end for**
- 10: 按式 (21.14) 形成汇总势
- 11: 计算 $Z_e = \sum_{\mathbf{x}_R} B_R(\mathbf{x}_R)$
- 12: **if** $Z_e = 0$ **then**
- 13: 报告证据与模型不相容, 不输出条件概率
- 14: **else**
- 15: 令 $b_C = B_C/Z_e$ 、 $b_{C,D} = B_{C,D}/Z_e$
- 16: **end if**

完整传播后, 各团不仅吸收了全部证据, 还会对共享变量给出相同的分布。**校准** (calibration) 在这里指这种重叠边缘的一致性, 不是分类器置信度与经验频率之间的预测校准。它要求相邻团把非共享变量消去以后, 得到相同的分隔集势, 图 21.4 右侧的等式正是这项检查。

这个一致性可以直接由消息公式证明。对边 (C, D) , $m_{D \rightarrow C}$ 只依赖 $S_{C,D}$, 因此能提出关于 $C \setminus S_{C,D}$ 的求和号:

$$\begin{aligned}
 & \sum_{\mathbf{x}_{C \setminus S_{C,D}}} B_C(\mathbf{x}_C) \\
 &= m_{D \rightarrow C} \sum_{\mathbf{x}_{C \setminus S_{C,D}}} \phi_C \prod_{K \in N_T(C) \setminus \{D\}} m_{K \rightarrow C} \quad (21.16) \\
 &= m_{D \rightarrow C} m_{C \rightarrow D} = B_{C,D}.
 \end{aligned}$$

从 D 侧作同样的计算也得到 $B_{C,D}$ 。所以两个团对分隔集的汇总完全一致。第 21.5.1 节将进一步证明 B_C 确实是 q_e 的边缘; 仅有“相邻表一致”还不足以断定它们对应最初输入的模式。

报警例的双向消息与分隔集势见表 21.2。每一行固定同一个 h , 两条消息相乘就是两团共同认可的 H 权重; 列和 0.19070 给出证据概率。

还可以逐项检查两个团的汇总势。以下第一张表按 f 分行、 h 分列, 第

h	$m_{C_1 \rightarrow C_2}(h)$	$m_{C_2 \rightarrow C_1}(h)$	$B_{C_1, C_2}(h)$
0	0.83	0.0445	0.036935
1	0.17	0.9045	0.153765

表 21.2 报警证据下的双向消息和分隔集势。只有最后一列是 H 与证据的联合权重；单独一条消息不必是归一化分布。

二张按 h 分行、 s 分列；第二张只列 $a = 1$ 的切片， $a = 0$ 切片全为零：

$$\begin{aligned} [B_{C_1}(f, h)]_{f, h} &= \begin{pmatrix} 0.036045 & 0.081405 \\ 0.000890 & 0.072360 \end{pmatrix}, \\ [B_{C_2}(h, 1, s)]_{h, s} &= \begin{pmatrix} 0.007885 & 0.029050 \\ 0.145350 & 0.008415 \end{pmatrix}. \end{aligned} \quad (21.17)$$

第一张表按列求和，第二张表按行求和，都得到 $(0.036935, 0.153765)$ 。各表的总和也都等于 0.19070。这同时核对了因子分配、消息方向与校准；不必另做一次完整枚举才知道两个团的重叠部分是否一致。

若消息已独立缩放，应分别将团汇总势归一化，再比较它们在分隔集上的概率边缘；不应要求那些带有不同任意尺度的原始表直接相等。构造可复用的局部表示并吸收、传播证据，是经典精确图模型推断的核心思路³。

³S. L. Lauritzen, D. J. Spiegelhalter, *Local Computations with Probabilities on Graphical Structures and Their Application to Expert Systems* In Journal of the Royal Statistical Society: Series B (Methodological), 1988, vol. 50, no. 2, pp. 157–194

21.4.3 查询与证据更新

校准以后，若查询集合 Q 包含于某个团 C ，答案就是

$$p(\mathbf{x}_Q | \mathbf{e}) = \sum_{\mathbf{x}_{C \setminus Q}} b_C(\mathbf{x}_C). \quad (21.18)$$

无需重新传播消息，但仍要完成团表内部的边缘化，并写出所需输出。在报警例中， F, H 由 C_1 覆盖， H, S 由 C_2 覆盖；分别消去另一个变量即可得到 $p(F = 1 | A = 1) \approx 0.384111$ 与 $p(S = 1 | A = 1) \approx 0.196460$ 。

查询 $\{F, S\}$ 却没有被任何一个团共同覆盖。虽然两个团的汇总势都已经正确，它们各自都包含了全图证据；直接相乘会重复使用重叠部分的信息。在本例中，正确拼接为

$$p(f, s | A = 1) = \frac{1}{Z_e} \sum_h \frac{B_{C_1}(f, h) B_{C_2}(h, 1, s)}{B_{C_1, C_2}(h)}. \quad (21.19)$$

两个分母值在本例中均为正。以 $(f, s) = (0, 0)$ 为例，归一化之前的两项为

$$\begin{aligned} & \frac{0.036045 \times 0.007885}{0.036935} + \frac{0.081405 \times 0.145350}{0.153765} \\ &= 0.007695 + 0.076950 = 0.084645. \end{aligned}$$

式中除去一个分隔集势，恰好撤掉重复的 H 权重。四组结果见表 21.3，与直接消去 H 得到的联合表一致。

f	s	$p(f, s, A = 1)$	$p(f, s A = 1)$
0	0	0.084645	0.443865
0	1	0.032805	0.172024
1	0	0.068590	0.359675
1	1	0.004660	0.024436

表 21.3 没有单团覆盖的查询 $\{F, S\}$ 。未列为四舍五入值；联合表不能由两个一元后验相乘得到，也不能由未经分隔集修正的团势乘积得到。

遗漏分隔集修正并不是只差一个全局常数。若错误地将两个团汇总势直接相乘，再消去 H ，会得到

$$\tilde{q}(f, s) = \sum_h B_{C_1}(f, h) B_{C_2}(h, 1, s).$$

对 $\tilde{q}$ 整体归一化，所得故障概率约为 0.446232，而正确值是 0.384111。额外乘入的 $B_{C_1, C_2}(h)$ 随 h 改变，归一化无法消去这种状态相关的偏差。

一般的跨团查询可以只处理覆盖查询变量的连通子树。为每个查询变量选择一个包含它的团，将连接这些团的子树的团集合记为 $\mathcal{H} \subseteq \mathcal{C}$ ，并令 $W = \bigcup_{C \in \mathcal{H}} C$ 。外部各分支已有消息，将它们吸收到子树内的局部势：

$$\begin{aligned} \tilde{\phi}_C &= \phi_C \prod_{D \in N_{\mathcal{T}}(C) \setminus \mathcal{H}} m_{D \rightarrow C}, \\ g_Q(\mathbf{x}_Q) &= \sum_{\mathbf{x}_{W \setminus Q}} \prod_{C \in \mathcal{H}} \tilde{\phi}_C(\mathbf{x}_C), \\ p(\mathbf{x}_Q | \mathbf{e}) &= g_Q(\mathbf{x}_Q) / Z_{\mathbf{e}}. \end{aligned} \quad (21.20)$$

运行交集保证每个外部分支只通过对应分隔集与子树连接，因此这些入站消息已经完成对 $V \setminus W$ 的求和。子树内部再执行变量消除即可，不需要显式展开 W 上的全部联合表。这种形式复用了校准时的消息，且没有除法，在含零势时也成立。

如果只保存了校准后的团边缘和分隔集边缘，也可以在它们的正支持上使用

$$p(\mathbf{x}_W | \mathbf{e}) = \frac{\prod_{C \in \mathcal{H}} b_C(\mathbf{x}_C)}{\prod_{(C, D) \in \mathcal{E}_{\mathcal{H}}} b_{C, D}(\mathbf{x}_{S_{C, D}})}, \quad (21.21)$$

再消去 $W \setminus Q$ ，其中 $\mathcal{E}_{\mathcal{H}}$ 为子树内部的边集。将式 (21.14) 代入可见，每条内部边的两条消息恰好各被约去一次，留下 $\prod_C \tilde{\phi}_C$ ；分子比分母多一个归一化因子，留下 $1/Z_{\mathbf{e}}$ 。这就给出了该拼接公式的依据，而不是假定团边缘相互独立。

当某个分隔集状态概率为零时，与它一致的完整配置也只能有零概率，

不能在该处机械计算 $0/0$ 。可直接使用无除法的式 (21.20)；也可给子树定根，仅在分隔集概率为正的状态上形成 $b_C/b_{C,D}$ 作为条件表，从零概率父状态到达的分支整体记为零。式 (21.21) 据此按支持集延拓。若只需几个边缘，这比拼出全联合表节省计算；若要求输出很大的联合表，输出成本本身仍不能避免。

MPE 查询必须使用另一套最大积消息。对团间消息中的求和换成最大化，得到 $\nu_{C \rightarrow D}$ ，并记录

$$\rho_{C \rightarrow D}(\mathbf{x}_{S_{C,D}}) \in \arg \max_{\mathbf{x}_{C \setminus S_{C,D}}} \left\{ \phi_C \prod_{K \in N_{\mathcal{T}}(C) \setminus \{D\}} \nu_{K \rightarrow C} \right\}. \quad (21.22)$$

在根团选择最佳配置，再按已确定的分隔集状态向外回溯。运行交集保证与先前已赋值变量的重叠全部位于分隔集中，所以回溯不会为同一变量给出冲突赋值。若只求一组 MPE，最大积收集加回溯已经足够；若需各团的最大边缘，可以另做双向最大积校准。它的重叠一致性使用最大化，不是求和，汇总势也不再表示概率边缘。已完成的和积消息不能在查询时临时“改成最大化”使用；即使根据和积校准结果重建了联合分布，仍需重新完成所需最大化和回溯运算。

证据更新与更换查询不同，它可能让缓存失效。设 $\mathcal{D}$ 为局部势发生变化的团集合。根据消息的一侧子树含义， $m_{C \rightarrow D}$ 只依赖 $\mathcal{C}_{C|D}$ 侧的局部势，因此

$$\mathcal{C}_{C|D} \cap \mathcal{D} = \emptyset \implies m_{C \rightarrow D} \text{可原样复用}. \quad (21.23)$$

反之，只要源侧包含变化团，就应将消息视为可能失效；特殊数值可能使它恰好不变，但仅凭图结构不能作此保证。式 (21.23) 描述的是依赖范围，而不是宣称每次证据变化都一定改变其中每个数值。

若只有 C_0 变化，以它为根，则所有指向 C_0 的消息都不依赖 ϕ_{C_0} ，可以保留；只需沿远离 C_0 的方向重新分发，总计重算每条边的一个方向。图 21.5 展示了这一点。虽然只改了一个局部输入，全树团边缘都可能变化。若只查询团 C_q 覆盖的变量，只需将变化沿 C_0 到 C_q 的唯一路径传过去，其他分支向该路径发来的消息仍有效；尚未刷新的团边缘应保持失效标记，不能当成新证据下的答案。多个团同时变化时，对每个消息应用同一源侧判据，某些边的两个方向都可能需要重算。

在报警例中，新加入 $S = 0$ 时只改变 C_2 。保留 $m_{C_1 \rightarrow C_2} = (0.83, 0.17)$ ，重算反向消息为 $(0.0095, 0.855)$ ，得到 $Z_e = p(A = 1, S = 0) = 0.153235$ 和 $p(F = 1 | A = 1, S = 0) = 0.068590/0.153235 \approx 0.447613$ 。若从只有 $A = 1$ 的情形改为 $A = 0$ ，反向消息变为 $(0.9555, 0.0955)$ ，证据概率为 0.80930 ，故障后验为 $0.02675/0.80930 \approx 0.033053$ 。两种更新都没有理由重算故障侧的先验汇总。




图 21.5 仅 C_0 的局部势改变时的更新方向。实线箭头沿远离 C_0 的方向传播新贡献，反向虚线箭头表示仍可复用的消息；团节点只画名称，具体变量集合须满足运行交集。查询 C_2 时只需更新路径 $C_0 - C_1 - C_2$ ，其他团的旧边缘不因路径更新而自动全部有效。

证据撤回不能简单用新指示函数除以旧指示函数。旧硬证据可能把一整片表项置零，除法无法恢复原数值。应保留 ϕ_C^0 及各条当前证据，按式 (21.12) 重建受影响的局部势，再按依赖方向重算消息；缩放常数也属于缓存状态，需要同步更新。若曾为某一证据取值删去变量或裁剪图结构，撤回时还须恢复相应结构。

固定团树能够处理被现有团覆盖的证据因子或原有因子的数值变化；它不保证覆盖新加入的多变量似然或结构边。新作用域若不在任何现有团中，就需要重新组织因子、扩大团或重新三角化，不能只把新函数塞入一个不覆盖它的团。相互矛盾的硬证据使 $Z_e = 0$ 时，消息代数仍能计算零权重，但条件后验没有定义。证据更新的正确性必须同时检查缓存依赖、因子覆盖和归一化条件。

21.5 算法分析

21.5.1 正确性与校准

局部校准等式只说明两个邻团彼此一致。为了证明它们一致地表示了输入模型，还要把一条消息与明确的全局求和联系起来。以下定理给出这种联系，也为跨团查询和证据更新提供依据。

定理 21.3 子树消息与团边缘 设 V 为有限变量索引集，每个 X_i 的状态空间有限非空； $\mathcal{T} = (\mathcal{C}, \mathcal{E}_{\mathcal{T}})$ 是以 V 的子集为团节点、满足 $\bigcup_{C \in \mathcal{C}} C = V$ 和运行交集性质的有限树。有限个取有限非负值的因子与证据因子恰好各分配给一个覆盖其作用域的团，所得团势为 ϕ_C ，并记未归一化目标 $q_e(\mathbf{x}) = \prod_{C \in \mathcal{C}} \phi_C(\mathbf{x}_C)$ 。对边 (C, D) ，令 $S_{C,D} = C \cap D$ ；

删除该边后，记 C 侧的团集合为 $\mathcal{C}_{C|D}$ ，并令 $U_{C|D} = \bigcup_{K \in \mathcal{C}_{C|D}} K$ 。若按式 (21.13) 完成全部未缩放和积消息，则对每条有向边 $C \rightarrow D$ ，

$$m_{C \rightarrow D}(\mathbf{x}_{S_{C,D}}) = \sum_{\mathbf{x}_{U_{C|D} \setminus S_{C,D}}} \prod_{K \in \mathcal{C}_{C|D}} \phi_K(\mathbf{x}_K). \quad (21.24)$$

完整传播后，定义

$$\begin{aligned} B_C(\mathbf{x}_C) &:= \phi_C(\mathbf{x}_C) \prod_{K \in N_{\mathcal{T}}(C)} m_{K \rightarrow C}(\mathbf{x}_{S_{K,C}}), \\ B_{C,D}(\mathbf{x}_{S_{C,D}}) &:= m_{C \rightarrow D}(\mathbf{x}_{S_{C,D}}) m_{D \rightarrow C}(\mathbf{x}_{S_{C,D}}), \\ Z_e &:= \sum_{\mathbf{x}_V} q_e(\mathbf{x}). \end{aligned}$$

则对任意团 C 及边 (C, D) ，

$$\begin{aligned} B_C(\mathbf{x}_C) &= \sum_{\mathbf{x}_{V \setminus C}} q_e(\mathbf{x}), \\ B_{C,D}(\mathbf{x}_{S_{C,D}}) &= \sum_{\mathbf{x}_{V \setminus S_{C,D}}} q_e(\mathbf{x}). \end{aligned} \quad (21.25)$$

若 $Z_e > 0$ ，则 B_C/Z_e 与 $B_{C,D}/Z_e$ 分别为相应的后验团边缘和后验分隔集边缘。

证明. 对 $\mathcal{C}_{C|D}$ 中的团数归纳。若这一侧只有叶团 C ，式 (21.24) 就是 $\sum_{\mathbf{x}_{C \setminus S_{C,D}}} \phi_C$ ，与叶消息公式相同。

对一般的 C ，删去 C 以后，除 D 侧外的每个邻团 K 带来一个分支。记其内部变量集合为 $R_K = U_{K|C} \setminus S_{K,C}$ 。运行交集保证 R_K 与 C 不相交：若变量同时在 K 侧某团和 C 中出现，路径经过 K ，它就必须属于 $S_{K,C}$ 。不同 R_K 也不相交，否则连接两分支中该变量的路径经过 C ，再次迫使它属于 C ，与内部变量的定义矛盾。

因而 $U_{C|D} \setminus S_{C,D}$ 可以拆为 $C \setminus S_{C,D}$ 和这些互不相交的 R_K 。固定 $\mathbf{x}_C$ ，分支中的求和可独立进行；由归纳假设，每个分支的结果恰好是 $m_{K \rightarrow C}$ 。有限求和的分配律给出

$$\begin{aligned} & \sum_{\mathbf{x}_{U_{C|D} \setminus S_{C,D}}} \prod_{L \in \mathcal{C}_{C|D}} \phi_L \\ &= \sum_{\mathbf{x}_{C \setminus S_{C,D}}} \phi_C \prod_{K \in N_{\mathcal{T}}(C) \setminus \{D\}} \left[\sum_{\mathbf{x}_{R_K}} \prod_{L \in \mathcal{C}_{K|C}} \phi_L \right] \\ &= \sum_{\mathbf{x}_{C \setminus S_{C,D}}} \phi_C \prod_{K \in N_{\mathcal{T}}(C) \setminus \{D\}} m_{K \rightarrow C}. \end{aligned}$$

最后一行正是消息更新式，归纳完成。

对任意团 C ，将所有邻接分支都纳入上述分解。各分支内部变量互不重叠，且与 C 合起来覆盖 V ；各局部势的乘积又恰为 q_e 。因此先消去分支内部变量，所得结果为 $\phi_C \prod_K m_{K \rightarrow C} = B_C$ ，证明了第一个边缘等式。再把 $C \setminus S_{C,D}$ 消去，利用式 (21.16) 得到 $B_{C,D}$ ，证明第二个等式。两者的全状态求和均为 Z_e ，在其为正时除以它即可。 ■

证明中的关键不是“树上的计算天然正确”，而是运行交集使各分支的内部变量真正互不重叠，唯一分配使因子既不遗漏也不重复。分隔集保存全部共享变量，分配律才允许把全局求和拆成局部消息。任意构造一组相邻一致的表，最多说明它们可在合适的树上拼成某个分布；若不检查这些表与原始因子乘积的关系，就不能据此认定它们是所求模型的边缘。

同样的归纳把求和换成最大化，就得到最大积消息的子树最优值含义，因为非负乘法对独立变量组上的最大化仍满足所需分配律。回溯进一步保证取得该值的配置能够拼接：给定分隔集，记录的局部最优选择达到发送消息的数值；沿树展开时，已赋值部分与未展开分支的交集只在分隔集中。逐步代入这些选择，最终联合权重等于根处最大值。若根处最大值为零，则不存在正权重的相容配置，不能将任意零权重配置报告成有定义的条件 MPE。

这些证明不要求所有表项严格为正，严格正性只会简化涉及比值的重构。推广到连续变量时，求和应换成积分，并要求存在适当密度、归一化常数有限且为正，以及各局部积分能够精确完成。非负函数可借助 Tonelli 定理交换积分，但这个代数事实不保证一般函数的积分存在闭式表达，更不能把连续观测的单点指示函数直接照搬为离散硬证据。

21.5.2 与变量消除的关系

三角化本来就是变量消除产生的图结构记录。消去 v_i 时，把当前涉及它的因子相乘，乘积作用域落在 $\{v_i\} \cup N_i^+$ 内；消去 v_i 后产生的新因子作用在 N_i^+ 上。这与定理 21.2 证明中集合 K_i 向父集合发送的消息具有相同边界。把各个消元集合保留下来，便得到一种以中间因子为边的计算树。

若将包含在相邻大集合中的非极大集合收缩掉，就得到更紧凑的团树。收缩相当于把数步局部消元合并为一次团间消息。因此，一条极大团之间的消息可能对应一组变量的连续消除，而不一定与单个变量消除步骤一一对应；没有必要强行给每张中间表找一个独立极大团。

反过来，给定一棵团树并选定根，可以从叶团开始消去该团不属于父分隔集的变量。运行交集保证这些变量不会在尚未处理的其他团中出现，所以可以在此时消去。将所得分隔集因子送到父团，再继续处理，恰好得到

团树的收集阶段。这说明两种方法使用相同的乘法和边缘化，并拥有相同的正确性依据，只是组织中间结果的方式不同。

报警例中，以 $C_1 = \{F, H\}$ 为根， C_2 中的 A, S 通过指示证据和求和被消去，生成 $u(h)$ ；根再对 H 求和便得到故障查询。以 C_2 为根时，另一方向消去 F 得到 $v(h)$ 。团树把这两个方向的结果同时保存，因此后续查询 F, H, S 的边缘无需各自重走一遍原始消元。

团树的优势应与任务口径一起理解。只问一次、只需一个目标边缘时，合适的变量消除可以及时释放不用的中间表，未必需要全树分发。固定模型上反复读取不同团覆盖的边缘、或在局部修改证据时，保存双向消息才会带来持续复用。变量消除也可以实现缓存；团树提供的是一套可检查的缓存依赖与失效规则，而不是一种绕过消元计算的独立原理⁴。

⁴ D. Koller, N. Friedman, *Probabilistic Graphical Models: Principles and Techniques*, MIT Press, 2009

21.5.3 复杂度与适用边界

消息数量随树边数线性增长，不意味着其算术成本只随原图节点数线性增长。令 $k = |\mathcal{C}|$ 、 $r_i = |\mathcal{X}_i|$ ，定义团与分隔集的表规模

$$r_C = \prod_{i \in C} r_i, \quad r_{C,D} = \prod_{i \in S_{C,D}} r_i. \quad (21.26)$$

一条 $C \rightarrow D$ 消息输出 $r_{C,D}$ 个数，但在通用稠密表格实现中，通常需要遍历 r_C 个团状态，组合局部势和入站消息，再将它们累加到分隔集相应位置。较小的输出表不能消除形成它所需的团内枚举。

记 $\deg(C)$ 为团的度。单独逐条计算 C 的每个出站消息，每条都重新乘所有其他入站消息，会带来 $O(\deg(C)^2 r_C)$ 的重复乘法。可以在每个团状态上计算邻居消息值的前缀积、后缀积，以 $O(\deg(C))$ 次乘法得到排除任意一个邻居的乘积，再分别累加到消息表。这个方法也适用于零表项，不需要用“总乘积除以被排除消息”。结合收集与分发调度，完整传播的时间可界为

$$O\left(\sum_{C \in \mathcal{C}} (\deg(C) + 1) r_C\right), \quad (21.27)$$

这里假设局部势已经建立，因子表索引等基本操作耗时有界；加 1 还计入形成团汇总势的成本。未采用这种复用的实现应如实保留额外度数因子。

保存局部势、团汇总势和两套方向消息，持久内存的量级为

$$O\left(\sum_{C \in \mathcal{C}} r_C + 2 \sum_{(C,D) \in \mathcal{E}_T} r_{C,D}\right), \quad (21.28)$$

还应另计输入因子、工作缓冲区与最大积回溯记录。前缀积和后缀积可以逐个团状态临时形成，不必把每个邻居的完整团维度副本永久保存。只保留消息而按需重建团边缘也能减少常数开销，但不能消除大团状态空间。

若每个变量至多有 r 个状态，所选三角化的最大团大小为 $w + 1$ ，则 $r_C \leq r^{w+1}$ 。利用树上 $\sum_C \deg(C) = 2(k - 1)$ ，式 (21.27) 给出 $O(kr^{w+1})$ 的传播上界；若有 m 个原始因子，按稠密表格建立局部势的保守上界为 $O(mr^{w+1})$ 。不同极大团的分隔集大小至多为 w ，消息表不超过 r^w ，但团势表仍需要 r^{w+1} 项。这里 w 是已选消元顺序的诱导宽度；只有在最优三角化下，它才等于原交互图的树宽。

状态数不同时，只比较团中变量个数也不够。对于图 21.2 的四环，假设 $r_1 = r_3 = 10$ 、 $r_2 = r_4 = 2$ ，两种三角化的开销如表 21.4。最大团都含三个变量，但团表与分隔集表的规模明显不同。这提示排序启发式还应考虑各变量状态数，而非只数新增边。

填充边	极大团	各团表项数	分隔集表项数
1 - 3	$\{1, 2, 3\}, \{1, 3, 4\}$	200, 200	100
2 - 4	$\{1, 2, 4\}, \{2, 3, 4\}$	40, 40	4

表 21.4 同一四环的两种精确编译。这里比较人工设定的状态空间规模，不比较概率值；两种选择的未加权树宽都为 2。

指数开销很快会超过缓存带来的收益。一个含 30 个二元变量的团需要 2^{30} 个表项，仅一张双精度表就占 8 GiB，尚未计入其他团、消息与工作空间。最大权生成树的选择不能缩小已经形成的极大团；局部证据更新虽然可能只重算一部分消息，最坏情况下仍会把变化传播到全树。非单团覆盖的联合查询还需要额外局部消元，其受限消元顺序和输出表规模也可能远大于单团边缘查询。

这些界针对任意稠密离散势，并非所有函数表示都按状态组合制表。例如高斯势可以通过精度矩阵与一次项表示，积分消息对应块矩阵消元，其开销由矩阵维数和填充控制，而不是 r^{w+1} 。但这种优势依赖函数族在乘法和积分下的闭包；混合分量增长或一般非线性势会破坏简洁表示。不能只因为图被编成一棵树，就把局部积分、最优化或大表枚举都当成常数操作。

团树适合因子作用域固定、编译成本可以摊销、且最大团可容纳的重复推断任务。若树宽或状态空间已经过大，完整精确表格本身无法保存，团树不会通过复用使它突然可行。直接在有环图上迭代消息属于另一条路线，其固定点与误差问题留到第 22.2.4 节；这些近似算法不能继承本章依赖树分隔与运行交集的精确性证明。

21.6 本章小结

变量消除产生的中间因子之所以能够复用，是因为它概括的是一侧子问题对边界变量的完整贡献，而不只是某次查询中的临时数值。树状因子图直接提供这种边界；一般图则通过道德化、三角化和团树构造，把需要共同

保留的变量放到团与分隔集中。运行交集保证两侧共享的变量没有遗漏，唯一因子分配保证原始乘积没有被改写。

在这些条件下，收集与分发完成对子树贡献的精确汇总。当证据归一化常数 $Z_e > 0$ 时，校准后的团汇总势 B_C 除以 Z_e ，给出真实后验边缘；局部团势 ϕ_C 仍保存本团负责的输入因子与证据。被单团覆盖的查询可以局部读取；跨团查询需要利用分隔集修正或已有边界消息继续消元，不能把多个团边缘直接相乘。MPE 使用独立的最大积传播与回溯，证据更新则依据每条消息的源侧依赖判断失效，并在撤回硬证据时从原始势恢复信息。


团树没有改变精确推断的局部代数，却把计算结果与依赖关系显式保存下来。因此，固定模型上的多次查询能够共享计算，局部证据变化也能保留不受影响的消息。复用减少的是重复劳动，不是最大团状态空间：树宽、变量状态数和查询输出规模仍决定这条精确路线能走多远。

变分推断与确定性近似

局部因子很小，联合推断仍可能很贵。第 20 章和第 21 章通过消元与团树保存了依赖关系；当中间团过大时，保存这些关系本身就成为瓶颈。此时可以改变问题：不再要求把后验完整算出来，而是在一个可计算的分布集合中寻找替代品。另一些任务只需要一组最可能的配置，则可以放宽配置必须满足的约束，先求一个较容易的优化问题。两条路线都把推断改写为优化，但前者近似的是概率分布，后者近似的是离散决策，不能用同一种“准确率”概括。

本章把模型参数视为已知。第一类查询以观测 $\mathbf{x}$ 和潜变量 $\mathbf{z}$ 的后验 $p(\mathbf{z} | \mathbf{x})$ 为目标，输出合法近似分布、伪边缘或局部高斯近似，以便继续计算边缘概率和期望；第二类查询把证据吸收到因子中，输出全部未观测变量的一组联合最优配置，即最可能解释 (most probable explanation, MPE)。选择怎样的近似对象、怎样衡量误差，以及怎样实际求解，是三个不同的决定。两类查询共享变分几何和局部计算工具，却不能用一类输出替代另一类答案。

图 22.1 从查询需求分流：需要边缘概率、期望或不确定性时，进入第 22.2 节；只需全部未观测变量的一组最大得分配置时，进入第 22.3 节。图中方法名是后文的阅读入口，不必预先掌握；同一分支内的近似族、计算组织与优化方式还可以组合。共同的优化表示在下一节建立。



22.1 变分推断的统一视角

设 $p(\mathbf{x})$ 有限且为正；连续观测时，这里指观测位置的边缘密度。选取容易归一化、求期望或采样的分布族 $\mathcal{Q}$ ，用 $q \in \mathcal{Q}$ 代替难以直接计算的后验。

变分推断 (variational inference, VI) 就是把寻找后验的任务变成选择分布的优化问题。它仍然输出不确定性，只是不再允许任意复杂的依赖关系。

为说明目标怎样得到，以下积分同时代表连续积分或离散求和，且 q 与 p 相对于同一基准测度定义。假设 q 不在 $p(\mathbf{x}, \mathbf{z}) = 0$ 处放置正质量，所需期望有限。由 $p(\mathbf{z} | \mathbf{x}) = p(\mathbf{x}, \mathbf{z}) / p(\mathbf{x})$,

$$\begin{aligned} \text{KL}(q \| p(\cdot | \mathbf{x})) &= \mathbb{E}_q[\log q(\mathbf{Z}) - \log p(\mathbf{x}, \mathbf{Z})] + \log p(\mathbf{x}), \\ \mathcal{L}(q) &:= \mathbb{E}_q[\log p(\mathbf{x}, \mathbf{Z})] + H(q), \\ \log p(\mathbf{x}) &= \mathcal{L}(q) + \text{KL}(q \| p(\cdot | \mathbf{x})). \end{aligned} \quad (22.1)$$

其中 $H(q) = -\mathbb{E}_q \log q$ 是离散熵或相对于指定测度的微分熵。**证据下界** (evidence lower bound, ELBO) $\mathcal{L}(q)$ 是可由联合分布和 q 计算的量，不需要知道后验归一化常数。KL 散度非负，所以 $\mathcal{L}(q) \leq \log p(\mathbf{x})$ ；等号成立当且仅当 q 与后验几乎处处相同。模型固定时，对 $\mathcal{Q}$ 最大化 ELBO 等价于最小化 $\text{KL}(q \| p)$ ，称为反向 KL 方向。这里的“反向”只约定参数顺序，不表示 KL 具有对称性。

式 (22.1) 还分清了三类偏差。近似族过小, 即使找到最优 q^* 也无法表示后验, 这是近似族限制。把反向 KL 换成正向 KL、矩匹配或其他目标, 改变的是“接近”的含义。实际算法停在 $\hat{q}$, 还会留下 $\mathcal{L}(q^*) - \mathcal{L}(\hat{q})$ 的优化误差。若上确界没有达到, 可用上确界代替 $\mathcal{L}(q^*)$ 。增加迭代只能尝试减少第三项, 不能自动补回近似族已删去的依赖。

反向 KL 在 q 分配质量的位置评估误差。若 q 在 $p = 0$ 的区域放置正质量, KL 会变成无穷大, 因此近似分布必须避开目标不允许的位置。这是对目标零区域的回避; 从 q 的角度, 文献通常称其为**零强制** (zero forcing): 目标为零会迫使近似也为零。相对地, 正向 KL($p||q$) 的**零回避** (zero avoiding) 要求 q 不能在 p 有正质量的位置为零。两种叫法关注的是 q , 不能仅凭“回避”二字判断 KL 方向¹。

目标处处为正但存在低密度谷时, 单峰 q 覆盖两个相隔很远的模态, 可能需把许多质量放进谷底; 只覆盖一个模态则不必为另一个模态逐点支付损失。这解释了反向 KL 常见的模态选择倾向, 却不是所有分布或所有近似族上的定理。足够丰富的混合分布族可以同时保留多个模态, 单峰目标也未必产生模态遗漏。

一个可解析的例子能更准确地说明方差低估。设目标是零均值二维高斯, 协方差为

$$\Sigma = \begin{pmatrix} 1 & r \\ r & 1 \end{pmatrix}, \quad |r| < 1,$$

并限制 $q = \mathcal{N}(\mathbf{m}, \text{diag}(v_1, v_2))$ 。记精度矩阵 $\Lambda = \Sigma^{-1}$, 高斯 KL 的有关项为

$$\frac{1}{2} \left\{ \mathbf{m}^\top \Lambda \mathbf{m} + \sum_i \Lambda_{i,i} v_i - \sum_i \log v_i \right\}.$$

对 $\mathbf{m}$ 和 $v_i > 0$ 求导得到 $\mathbf{m} = \mathbf{0}$ 、 $v_i = 1/\Lambda_{i,i} = 1 - r^2$ 。取 $r = 0.8$ 时, 目标的两个边缘方差均为 1, 最优独立近似却均为 0.36。它选择的宽度接近给定另一坐标后的条件宽度, 避免把质量放在狭长高斯等高线之外。相反, 最小化 KL($p||q$) 会匹配边缘矩, 得到 $v_i = 1$ 。这个计算证明了当前高斯设定下的低估, 不证明所有反向 KL 近似都低估所有方向的方差。

要把这类分布优化与图上的局部计算联系起来, 需要一种以期望代替分布参数的表示。**指数族** (exponential family) 把对数密度写成若干固定统计量的线性组合:

$$\begin{aligned} p_\theta(\mathbf{z}) &= h(\mathbf{z}) \exp\{\langle \theta, \mathbf{T}(\mathbf{z}) \rangle - A(\theta)\}, \\ A(\theta) &= \log \int h(\mathbf{z}) e^{\langle \theta, \mathbf{T}(\mathbf{z}) \rangle} d\mathbf{z}. \end{aligned} \quad (22.2)$$

θ 是**自然参数** (natural parameter), 决定各统计量怎样进入得分; $\mathbf{T}$ 是**充分统计量** (sufficient statistic), 收集密度依赖的数据特征; h 是不依赖参

¹ C. M. Bishop, *Pattern Recognition and Machine Learning*, Springer, 2006, 1st ed.

数的基准项。对数配分函数 A 保证归一化。若自然参数位于 $A < \infty$ 的开区间内，并允许交换微分与积分，则

$$\nabla A(\theta) = \mathbb{E}_\theta \mathbf{T}(\mathbf{Z}) =: \boldsymbol{\mu}, \quad \nabla^2 A(\theta) = \text{Cov}_\theta[\mathbf{T}(\mathbf{Z})]. \quad (22.3)$$

第一式来自对积分求导后除以归一化常数；对这一比值再求导就得到第二式。协方差矩阵半正定，因此 A 凸。 $\boldsymbol{\mu}$ 称为**均值参数** (mean parameter)，它直接记录期望统计量。若统计量之间没有非平凡的仿射冗余，即指数族是最小表示，则内部的协方差正定，自然参数与可实现均值参数之间才有通常的一一对应。完整指示统计量往往冗余，不能直接宣称其 Hessian 可逆。

以下对偶与多面体陈述先限定为有限离散状态、 $h = 1$ 。以 $V = \{1, \dots, d\}$ 记节点集， Z_i 的有限非空状态集为 $\mathcal{X}_i$ ，节点集 $A \subseteq V$ 上的配置集为 $\mathcal{X}_A = \prod_{i \in A} \mathcal{X}_i$ ，全部联合配置组成 $D = \mathcal{X}_V$ 。定义**边缘多面体** (marginal polytope)

$$\mathcal{M} = \{\mathbb{E}_q \mathbf{T}(\mathbf{Z}) : q \text{ 为全局分布}\} = \text{conv}\{\mathbf{T}(\mathbf{z}) : \mathbf{z} \in D\}, \quad (22.4)$$

其中 conv 表示凸包。当 $\mathbf{T}$ 由节点和因子配置的指示函数组成时， $\boldsymbol{\mu}$ 就是相应边缘概率； $\mathcal{M}$ 要求这些局部表格能够同时来自某个全局分布，而不只是每张表各自归一化。

定理 22.1 配分函数与最大熵的对偶 设 D 为有限非空配置集， $\mathbf{T} : D \rightarrow \mathbb{R}^m$ 为统计量，并对 $\theta \in \mathbb{R}^m$ 定义

$$A(\theta) = \log \sum_{\mathbf{z} \in D} \exp(\theta, \mathbf{T}(\mathbf{z})), \quad \mathcal{M} = \text{conv}\{\mathbf{T}(\mathbf{z}) : \mathbf{z} \in D\}.$$

令 q 遍历 D 上的全部概率质量函数， $H(q) = -\sum_{\mathbf{z} \in D} q(\mathbf{z}) \log q(\mathbf{z})$ ，其中 $0 \log 0 = 0$ ；并对 $\boldsymbol{\mu} \in \mathcal{M}$ 定义

$$H^*(\boldsymbol{\mu}) = \max_{q: \mathbb{E}_q \mathbf{T} = \boldsymbol{\mu}} H(q).$$

则凸共轭 $A^*(\boldsymbol{\mu}) := \sup_{\theta} \{\langle \theta, \boldsymbol{\mu} \rangle - A(\theta)\}$ 在 $\mathcal{M}$ 上等于 $-H^*(\boldsymbol{\mu})$ ，在 $\mathcal{M}$ 外等于 $+\infty$ ，并且

$$A(\theta) = \max_{\boldsymbol{\mu} \in \mathcal{M}} \{\langle \theta, \boldsymbol{\mu} \rangle + H^*(\boldsymbol{\mu})\}. \quad (22.5)$$

证明. 将式 (22.1) 用于未归一化函数 $\exp(\theta, \mathbf{T})$ ，得到

$$A(\theta) = \max_q \{\langle \theta, \mathbb{E}_q \mathbf{T} \rangle + H(q)\}.$$

最大值由 p_θ 取得。按相同的 μ 把分布分组，组内线性项不变，故只需选择熵最大的分布，得到式 (22.5)。

为说明这不只是单向不等式，在 $\mathcal{M}$ 上定义 $f = -H^*$ ，在外部定义 $f = +\infty$ 。任意两个均值约束下的最大熵分布可以混合，熵的凹性说明 H^* 凹，因此 f 凸。概率单纯形紧且熵连续；对任意收敛的均值参数序列，先选取最大熵值趋于上极限的子序列，再取相应分布的收敛子列。极限分布仍满足极限均值约束，故熵的上极限不超过该约束下的最大熵。这说明 H^* 上半连续；结合 $\mathcal{M}$ 闭，扩展后的 f 下半连续，也称为闭凸函数。

这里使用双共轭定理：适当、下半连续的凸函数满足 $f^{**} = f$ ，见 Rockafellar 的定理 12.2²。“适当”指不恒为 $+\infty$ 且不取 $-\infty$ ；本例 $\mathcal{M}$ 非空，而且 $0 \leq H^* \leq \log |D|$ ，因此满足此条件。上式已经证明 $f^* = A$ ，代入便得 $A^* = (f^*)^* = f$ 。这一论证也覆盖 $\mathcal{M}$ 边界，不要求边界均值由有限自然参数实现。 ■

² R. T. Rockafellar, *Convex Analysis*, Princeton University Press, 1970

这里的负熵必须读成“给定统计量后的最大熵的负值”。少量边缘统计量通常不能确定任意全局分布，其熵不能随便代入 A^* 。对一般基准项 h ，应把 $H(q)$ 替换成 $H(q) + \mathbb{E}_q \log h$ ；对连续变量，还需要可积性、闭性和对偶成立条件，均值可实现集合也通常不是有限多面体。指数族与变分对偶的系统处理见 Wainwright 和 Jordan 的专著式综述³。

³ M. J. Wainwright, M. I. Jordan, *Graphical Models, Exponential Families, and Variational Inference* In Foundations and Trends in Machine Learning, 2008, vol. 1, no. 1-2, pp. 1-305

式 (22.5) 指出了两处困难： $\mathcal{M}$ 的全局一致性约束可能很多， H^* 也可能难算。平均场限制全局分布，保留真实熵，因此得到下界；局部自由能方法同时替换可行集合和熵，不再自动保留下界；配置优化去掉熵，再扩大可行集合，则得到最大得分的上界。这些方向来自具体的包含关系，不来自“变分”这个名称。

同一坐标也能表示 MPE。令 $S(\mathbf{z}) = \langle \theta, \mathbf{T}(\mathbf{z}) \rangle$ 为吸收证据后的有限离散得分， D 为全部未观测变量的完整配置集合，则

$$\max_{\mathbf{z} \in D} S(\mathbf{z}) = \max_{\mu \in \mathcal{M}} \langle \theta, \mu \rangle. \quad (22.6)$$

右侧没有熵项，因为答案只需保留一个最大得分配置，而无须累计其他配置的概率质量。对数配分函数查询若替换 $\mathcal{M}$ 或 H^* ，误差落在分布、边缘或归一化常数上；MPE 若扩大 $\mathcal{M}$ ，则得到连续松弛及最大得分上界，还必须从松弛解恢复合法配置。这正是两条主线共享几何表示而输出、保证和诊断不同的原因。

这个变分表示提供了比较方法的依据，却不意味着所有方法都在近似同一个自由能。第 22.2.5 节的拉普拉斯近似改变众数附近的对数密度形状，EP 匹配临时倾斜分布的矩；它们不直接求解式 (22.5) 中的优化。第 22.3.1 节的 LP 则从无熵的式 (22.6) 出发，只放宽配置的一致性约束。比较时需要分别问：改变的是密度、局部矩，还是可行集合？

示例 22.2 三角图的精确基准 以下人工构造的二元模型贯穿本章。三个变量 $Z_i \in \{0, 1\}$ 组成三角图，每条边奖励端点取不同值：

$$p_\beta(\mathbf{z}) = \frac{\exp S_\beta(\mathbf{z})}{Z_\beta}, \quad S_\beta(\mathbf{z}) = \beta \sum_{(i,j) \in E} \mathbb{I}[z_i \neq z_j], \quad \beta = \log 2. \quad (22.7)$$

两个全相同配置的得分为 0，其余六个配置恰有两条不相等边，得分为 2β 。因此

$$Z_\beta = 2 + 6e^{2\beta} = 26, \quad p_\beta(Z_i = 1) = \frac{1}{2}, \quad p_\beta(Z_i \neq Z_j) = \frac{8}{13}.$$

每条边上，两个同值配置 (0,0) 与 (1,1) 各有概率 5/26；两个异值配置 (0,1) 与 (1,0) 各有概率 4/13。节点边缘都是均匀的，但节点并不独立；三个二元变量也不可能在每条边上都取不同值。

图 22.2 把同一模型的三种描述并列起来。删去依赖会丢失真实相关性，只检查每条边又可能接受根本不存在的联合配置。后面两类近似分别面对这两种风险。




图 22.2 三角图、完全因子化分布和局部一致的边缘表。右侧让每条边都以概率 1 取不同值，节点边缘仍都是 (1/2, 1/2)；它满足局部一致性，却不可能由任何全局二元分布实现。

22.2 近似后验分布与边缘概率

22.2.1 从平均场到结构化变分

选择后验近似时，要把“保留哪些依赖”与“怎样算出近似”分开。平均场与结构化 VI 选择近似分布族；VMP 组织共轭条件下的局部计算；SVI 通过小批量减少一次全局更新需要处理的数据。它们不是四种互斥模型：选好近似族以后，还可以利用共轭消息和随机优化求解。后面的局部自由能、拉普拉斯近似与 EP 则进一步改变所维护的对象或匹配准则。

最直接的计算简化是让每个潜变量只保留自己的不确定性。**平均场近**

似 (mean-field approximation) 采用

$$q(\mathbf{z}) = \prod_{i=1}^d q_i(z_i).$$

这一假设删去的是 q 中的后验依赖, 不是原模型中的边。原模型的耦合仍通过期望进入更新; 只是更新后的 q 无法表达 “一个变量改变时, 另一个变量的条件分布随之改变”。

固定除 q_i 之外的所有因子, 记 $q_{-i} = \prod_{j \neq i} q_j$, 并定义 $a_i(z_i) = \mathbb{E}_{q_{-i}} \log p(\mathbf{x}, z_i, \mathbf{Z}_{-i})$ 。ELBO 中依赖 q_i 的部分为

$$\int q_i(z_i) a_i(z_i) dz_i - \int q_i(z_i) \log q_i(z_i) dz_i.$$

假设 $C_i = \int e^{a_i(z_i)} dz_i$ 有限且为正, 令 $q_i^* = e^{a_i}/C_i$, 上述表达式就等于 $\log C_i - \text{KL}(q_i \| q_i^*)$ 。KL 在两分布相同时取唯一最小值, 因此得到最优坐标更新:

$$q_i^*(z_i) \propto \exp\{\mathbb{E}_{q_{-i}}[\log p(\mathbf{x}, z_i, \mathbf{Z}_{-i})]\}. \quad (22.8)$$

期望只对其他变量计算, z_i 在这一步是保留的自变量。更新使用的是对数联合分布的期望, 再取指数; 一般不等于 $\mathbb{E}_{q_{-i}} p(z_i | \mathbf{x}, \mathbf{Z}_{-i})$, 也不等于把其他变量一律替换为其均值。

若原模型按因子分解, 所有不含 z_i 的项都是归一化时可去掉的常数。平均场因此仍能局部更新。对例 22.2, 现在直接使用未归一化得分 S_β , 定义对数配分函数下界

$$\mathcal{L}_Z(q) = \mathbb{E}_q S_\beta(\mathbf{Z}) + H(q), \quad (22.9)$$

$$\text{KL}(q \| p_\beta) = \log Z_\beta - \mathcal{L}_Z(q).$$

因此 $\mathcal{L}_Z(q) \leq \log Z_\beta$ 。若使用已归一化的 p_β 计算 $\mathbb{E}_q \log p_\beta + H(q)$, 结果则是 $\mathcal{L}_Z(q) - \log Z_\beta \leq 0$, 两者相差一个与 q 无关的常数。令 $m_i = q_i(Z_i = 1)$, 并记 $\mathcal{L}_{\text{MF}}(\mathbf{m}) = \mathcal{L}_Z(\prod_i q_i)$, 则

$$\begin{aligned} \mathcal{L}_{\text{MF}}(\mathbf{m}) &= \beta \sum_{(i,j) \in E} (m_i + m_j - 2m_i m_j) + \sum_i h_B(m_i), \\ m_i^{\text{new}} &= \sigma \left(\beta \sum_{j \in N(i)} (1 - 2m_j) \right), \end{aligned} \quad (22.10)$$

其中 $\sigma(u) = 1/(1 + e^{-u})$, $h_B(m) = -m \log m - (1 - m) \log(1 - m)$, $N(i)$ 是相邻节点集合。若两个邻居的 m_j 均为 $1/4$, 新 $m_i = \sigma(\log 2) = 2/3$; 邻居偏好 0, 当前变量便更偏好 1。这不是硬性配置, 而是伯努利分布参数。

均匀初始化给出固定点 $m_i = 1/2$, 其对数配分函数下界为 $\mathcal{L}_{\text{MF}} = (9/2) \log 2 \approx 3.119162$, 低于 $\log 26 \approx 3.258097$ 。这一例中它还是平均场的

全局最优：目标 Hessian 的对角元不大于 -4 ，每行两个非对角元均为 -2β ，故最大特征值不超过 $-4 + 4\beta < 0$ ；目标在内部严格凹，熵导数又排除了边界最大点。然而 $q(Z_i \neq Z_j) = 1/2$ ，仍低于真实的 $8/13$ 。全局解出了近似问题，并不等于消除了近似误差。

算法 22.1 循环坐标平均场

输入： 联合分布、因子化近似族、有限 ELBO 的初值、容差 ϵ

输出： 近似分布 q 及其 ELBO

```

1: 计算当前 ELBO
2: repeat
3:   保存本轮开始时的 ELBO
4:   for  $i = 1, \dots, d$  do
5:     用其他因子的最新值计算式 (22.8)
6:     归一化并替换  $q_i$ 
7:   end for
8:   重新计算 ELBO 及本轮增量
9: until 增量不超过  $\epsilon$ ，或达到计算预算

```

算法 22.1 的每个精确坐标更新都不降低 ELBO，因为它解出了当前坐标的最大化问题。由于 ELBO 有上界，目标值序列收敛。这个论证不保证参数序列收敛，也不保证一般模型中的全局最优；同时用旧值并行更新所有坐标也不受这个逐坐标证明保护。

平均场让坐标更新变得局部，却可能恰好拆开后验中最重要的依赖。例如，相邻隐状态高度相关时，逐点独立近似会把一条连贯轨迹变成许多互不协调的边缘。**结构化变分推断**（structured variational inference）在 q 中保留选定的依赖，用较贵的局部推断换取更强的表达能力。

一种直接选择是把节点划分成互不相交的块 $B_1, \dots, B_K$ ，并让不同块独立，即

$$q(\mathbf{z}) = \prod_k q_k(\mathbf{z}_{B_k}).$$

与单变量推导相同，固定其余块后，当前块的最优分布满足

$$q_k^*(\mathbf{z}_{B_k}) \propto \exp \left\{ \mathbb{E}_{q_{-B_k}} \log p(\mathbf{x}, \mathbf{z}_{B_k}, \mathbf{Z}_{-B_k}) \right\}. \quad (22.11)$$

块内部原有相互作用被保留，跨块作用转成期望势。链与小树都可以沿用第 21.2.1 节的和积消息；在链上向两个方向传递消息，就是后文时序模型使用的前向-后向计算。若是稠密大块，更新仍会遇到指数级枚举。因此，块大小只是粗略指标，块内树宽和因子的代数结构才决定计算代价。

回到三角图，取 $q(z_1, z_2)q(z_3)$ 并令 $q(z_3 = 1) = 1/2$ 。两条跨块边的期

望得分总和恒为 β ，所以

$$q(z_1, z_2) = \frac{e^{\beta \mathbb{I}[z_1 \neq z_2]}}{2 + 2e^\beta}.$$

当 $\beta = \log 2$ 时，块内不同值的概率为 $2/3$ ，跨块边的不同值概率仍为 $1/2$ 。该解也是块坐标固定点；它给出的对数配分函数下界为 $\mathcal{L}_Z = \log(2 + 2e^\beta) + \beta + \log 2 = \log 24 \approx 3.178054$ ，高于完全平均场的 3.119162 ，但仍低于 $\log 26$ 。这里明确展示了增加结构保留了什么，也展示了两个尚未保留的相关性。

若 $\Omega_1 \subseteq \Omega_2$ ，对同一 ELBO 有 $\sup_{\Omega_1} \mathcal{L} \leq \sup_{\Omega_2} \mathcal{L}$ ；这只是优化范围扩大的结果，不保证有限预算下求得的解也按此顺序改进。更一般的树结构 q 未必能分成互不相交的块，可以用树边缘及条件分布参数化，其熵仍能精确计算。无论采用哪种结构，只有 q 是合法全局分布、期望和真实熵计算正确时，ELBO 下界才继续成立。结构化变分补回了选定依赖，却提高了每次坐标更新的成本；下一条路线固定近似族，转而利用共轭结构简化这些更新。

22.2.2 从坐标更新到变分消息传递

式 (22.8) 虽然形式简洁，指数中的期望仍可能难算。若完整条件分布属于指数族，

$$\log p(z_i | \mathbf{z}_{-i}, \mathbf{x}) = \log h_i(z_i) + \langle \boldsymbol{\eta}_i(\mathbf{z}_{-i}, \mathbf{x}), \mathbf{T}_i(z_i) \rangle + c(\mathbf{z}_{-i}, \mathbf{x}),$$

且相关期望存在，则更新后的 q_i 保持同一家族，自然参数为

$$\boldsymbol{\lambda}_i = \mathbb{E}_{q_{-i}} \boldsymbol{\eta}_i(\mathbf{Z}_{-i}, \mathbf{x}). \quad (22.12)$$

这就是条件共轭带来的计算闭合：期望改变参数，不改变函数形式。这里不要求 $\boldsymbol{\eta}_i$ 对其他变量线性，但必须能够计算其期望，并确认结果落在合法自然参数域内。

在因子图中，设每个邻接因子的对数中与 z_i 有关的部分能写成 $\langle \boldsymbol{\eta}_{a \rightarrow i}(\mathbf{z}_{S_a \setminus \{i\}}), \mathbf{T}_i(z_i) \rangle$ 。把 $\log h_i$ 只计入一次，定义消息

$$\mathbf{m}_{a \rightarrow i} = \mathbb{E}_{q_{S_a \setminus \{i\}}} \boldsymbol{\eta}_{a \rightarrow i}, \quad \boldsymbol{\lambda}_i = \sum_{a: i \in S_a} \mathbf{m}_{a \rightarrow i}.$$

变量再把 $\mathbb{E}_{q_i} \mathbf{T}_i$ 发给邻接因子，以供后续期望计算。**变分消息传递** (variational message passing, VMP) 就是这种以充分统计量和自然参数交换实现坐标优化的方式。消息不必是归一化概率表，也不同于和积算法对原因子先乘后求和的消息。它的基本闭式版本依赖所选因子化及条件共轭；非共轭模型需要局部界、数值积分或梯度更新，不能只写一句“传递消息”

便认为期望已有解析解⁴。

例如，全局成功率 $\Pi \sim \text{Beta}(a_0, b_0)$, $Z_i | \Pi \sim \text{Bernoulli}(\Pi)$, 观测因子为 $p(x_i | z_i)$ 。取 $q(\pi) \prod_i q_i(z_i)$, 记 $r_i = q_i(Z_i = 1)$, 便有

$$\begin{aligned} q(\pi) &= \text{Beta}(a, b), \\ a &= a_0 + \sum_i r_i, \quad b = b_0 + \sum_i (1 - r_i), \\ \log \frac{r_i}{1 - r_i} &= \mathbb{E}_q \log \Pi - \mathbb{E}_q \log(1 - \Pi) + \log \frac{p(x_i | 1)}{p(x_i | 0)}. \end{aligned} \quad (22.13)$$

其中 $\mathbb{E} \log \Pi = \psi(a) - \psi(a + b)$ 、 $\mathbb{E} \log(1 - \Pi) = \psi(b) - \psi(a + b)$, $\psi(u) = d \log \Gamma(u) / du$ 是双伽马函数。局部变量向全局因子发送的是软计数 ($r_i, 1 - r_i$), 全局变量返回的是期望对数概率, 而不是 $\log \mathbb{E} \Pi$ 。

取 $a_0 = b_0 = 1$, 两个样本的似然比分别为 4 和 1/4。从 $q(\pi) = \text{Beta}(1, 1)$ 开始, 局部更新给出 $r_1 = 0.8, r_2 = 0.2$; 全局更新得到 $\text{Beta}(2, 2)$ 。由于新的两个期望对数概率仍相等, 再次局部更新不变。计算过程只传递两个软计数及两个期望, 不枚举 (Z_1, Z_2, Π) 的联合状态; 代价是 q 不再保留 Π 与 Z_i 之间的后验相关。

22.2.3 从批量优化到随机与摊销推断

即使每个局部更新便宜, 遍历全部 n 个样本才能改变一次全局参数, 也会拖慢大数据推断。设全局潜变量为 $\mathbf{u}$, 样本局部潜变量为 $\mathbf{z}_i$,

$$p(\mathbf{u}, \mathbf{z}_{1:n}, \mathbf{x}_{1:n}) = p(\mathbf{u}) \prod_{i=1}^n p(\mathbf{x}_i, \mathbf{z}_i | \mathbf{u}), \quad q = q_{\lambda}(\mathbf{u}) \prod_i q_{\phi_i}(\mathbf{z}_i).$$

假设共轭使全局完整条件分布的自然参数等于 $\lambda_0 + \sum_i \mathbf{s}(\mathbf{x}_i, \mathbf{z}_i)$ 。固定局部因子时, 最优全局自然参数为 $\lambda^* = \lambda_0 + \sum_i \mathbb{E}_{q_i} \mathbf{s}_i$ 。

普通欧氏梯度没有考虑不同参数方向会引起多大的分布变化。**自然梯度** (natural gradient) 用 Fisher 信息矩阵校正梯度, 使更新按分布的局部几何衡量。在最小、正则指数族内部, 记全局对数配分函数为 A_q , 则 $\mathbf{F}(\lambda) = \nabla^2 A_q(\lambda)$ 。全局 ELBO 中依赖 λ 的部分为

$$\langle \lambda^* - \lambda, \nabla A_q(\lambda) \rangle + A_q(\lambda) + C.$$

求导得到 $\nabla_{\lambda} \mathcal{L} = \mathbf{F}(\lambda)(\lambda^* - \lambda)$, 从而

$$\tilde{\nabla}_{\lambda} \mathcal{L} = \lambda_0 + \sum_i \mathbb{E}_{q_i} \mathbf{s}_i - \lambda. \quad (22.14)$$

若局部因子已经达到给定全局参数下的最优值, 在可微等条件下, 包络定理允许用这同一偏导计算优化掉局部变量后的目标梯度。

⁴ J. Winn, C. M. Bishop, *Variational Message Passing* In Journal of Machine Learning Research, 2005, vol. 6, no. 23, pp. 661–694

均匀抽取大小为 b 的小批量 B , 更新其中局部因子后, 用

$$\begin{aligned}\hat{\lambda} &= \lambda_0 + \frac{n}{b} \sum_{i \in B} \mathbb{E}_{q_i} s_i, \\ \lambda^{(t+1)} &= (1 - \rho_t) \lambda^{(t)} + \rho_t \hat{\lambda}\end{aligned}\quad (22.15)$$

即可得到**随机变分推断** (stochastic variational inference, SVI)。在给定当前全局参数并精确求解相应局部问题时, 缩放的统计量是全数据和无偏估计。非均匀抽样需要按纳入概率加权; 局部更新不充分则还会引入偏差, 不能仅凭随机抽样宣称梯度无偏⁵。

在式 (22.13) 中, 若 $n = 1000$, 抽到的 10 个样本的 r_i 之和为 7, 先验仍为 $\text{Beta}(1, 1)$, 则小批量给出的目标分布是 $\text{Beta}(701, 301)$ 。若当前分布为 $\text{Beta}(501, 501)$, 取步长 0.1, 更新为 $\text{Beta}(521, 481)$ 。缩放发生在统计量而不是先验上, 否则会把先验重复计算。

常见递减步长满足 $\sum_t \rho_t = \infty, \sum_t \rho_t^2 < \infty$, 如 $\rho_t = (t+t_0)^{-\kappa}, 1/2 < \kappa \leq 1$ 。结合光滑性、迭代有界、噪声矩受控等随机逼近条件, 可以得到趋向驻点的结论; 这两个步长条件单独并不是完整收敛定理。每一步的 ELBO 也不必上升。局部更新负责解释当前样本, 全局更新负责汇总统计量, 两者的分工决定了小批量并行与内存节约。

至此可以按实际瓶颈选择组合。若主要关心单变量边缘、内存紧张, 完全平均场可作为成本较低的起点, 但仍需检查遗漏相关性是否影响所需统计量; 若需要相邻状态的联合概率或整段轨迹, 应考虑保留链或小块依赖, 并承担块内推断成本。增加结构是否值得, 要看这些依赖是否影响当前查询, 而不只看 ELBO 是否提高。

近似族选定后, 条件共轭且统计量期望可算时, 可用 VMP 组织更新; 它本身不补回被因子化删除的相关性。若瓶颈是遍历大量样本, 且模型具有上述可分解的局部统计量和全局更新, 则可叠加 SVI, 用有噪声的小批量更新换取较低的单步成本。例如每个样本是一段序列时, 可以在局部因子 $q_{\phi_i}(\mathbf{z}_i)$ 中保留整条链, 精确计算链内统计量, 再用小批量更新共轭的全局参数。这样同时用了结构化近似、可解析的消息计算和 SVI; 小批量并不会降低一条链内部的推断复杂度。

小批量减少了每次读取的数据, 却仍需为每个新样本求解局部优化。若样本不断到来, 可以学习一个共享映射 $\phi_i = f_{\omega}(\mathbf{x}_i)$, 直接输出 $q_{\phi_i}(\mathbf{z}_i)$ 的参数。**摊销推断** (amortized inference) 把许多样本的推断计算转移到一次共享训练中; 测试时主要执行前向计算, 也可以在其输出上继续作样本级优化。

非共轭模型下, ELBO 的期望通常用采样估计。对于能够写成 $\mathbf{z} = g_{\phi}(\epsilon)$ 、 $\epsilon \sim r(\epsilon)$ 且 r 不依赖 ϕ 的分布, 随机性可以与参数分开。例如高斯分布可写为 $\mathbf{z} = \mathbf{m} + \mathbf{L}\epsilon$, $\epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$, $\mathbf{L}\mathbf{L}^T$ 为协方差。令 $F_{\phi}(\mathbf{z}) = \log p(\mathbf{x}, \mathbf{z}) - \log q_{\phi}(\mathbf{z})$,

⁵ M. D. Hoffman, D. M. Blei, C. Wang, J. Paisley, *Stochastic Variational Inference* In Journal of Machine Learning Research, 2013, vol. 14, no. 4, pp. 1303–1347

在可交换微分与期望的可积支配条件下,

$$\begin{aligned}\nabla_{\phi}\mathcal{L} = \mathbb{E}_{\epsilon}[(\nabla_{\phi}g_{\phi})^{\top}\nabla_{\mathbf{z}}F_{\phi}(g_{\phi}(\epsilon)) \\ + \nabla_{\phi}F_{\phi}(\mathbf{z})|_{\mathbf{z}=g_{\phi}(\epsilon)}].\end{aligned}\quad (22.16)$$

第二行对 $\mathbf{z}$ 保持固定, 只微分 F 的显式参数依赖; 第一行则跟踪样本位置随参数移动的影响。这是**重参数化梯度** (reparameterization gradient), 也称路径导数估计: 先把期望写到固定噪声上, 再用链式法则求导。它不是把采样算子直接当成常数。模型也含待学习参数时, 应另加对应的显式偏导。一般推导可用于多种潜变量模型, 第 29 章将在 VAE 中实例化, 不再重复这一计算⁶。

以 $q = \mathcal{N}(m, s^2)$ 、 $s > 0$ 和 $f(z) = z^2$ 为例, $z = m + s\epsilon$, 路径导数的单样本估计分别是 $2(m + s\epsilon)$ 与 $2(m + s\epsilon)\epsilon$, 期望为 $2m$ 与 $2s$, 恰与 $\partial_m(m^2 + s^2)$ 、 $\partial_s(m^2 + s^2)$ 一致。有限样本估计仍有方差, “可重参数化” 不表示梯度无噪声, 也不无条件保证它比其他估计器方差小。

离散变量的普通采样映射对参数通常是阶梯函数, 几乎处处导数为零, 直接套用路径导数不能得到正确梯度。若支持集固定, 可改用

$$\nabla_{\phi}\mathbb{E}_{q_{\phi}}f_{\phi}(\mathbf{Z}) = \mathbb{E}_q[f_{\phi}(\mathbf{Z})\nabla_{\phi}\log q_{\phi}(\mathbf{Z}) + \nabla_{\phi}f_{\phi}(\mathbf{Z})]. \quad (22.17)$$

这称为**分数函数估计** (score-function estimator), 其中“分数”指对数密度对参数的导数。它从 $\nabla q = q\nabla\log q$ 直接得到。减去不依赖所采变量的基线不改变第一项期望, 因为 $\mathbb{E}_q\nabla\log q = 0$, 却可能降低方差。小状态空间也可以精确求和; 连续松弛则用可微随机变量替代离散变量, 一般改变了目标或引入偏差。支持集随参数变化时, 还必须处理积分边界, 不能照搬固定支持的等式。

摊销带来的速度收益应与误差分开衡量。为给出逐样本分解, 以下改用固定生成参数 θ 、样本间相互独立的局部潜变量模型, 并定义局部 ELBO:

$$\begin{aligned}p_{\theta}(\mathbf{x}_{1:n}, \mathbf{z}_{1:n}) &= \prod_i p_{\theta}(\mathbf{x}_i, \mathbf{z}_i), \\ \mathcal{L}_i(\phi) &= \mathbb{E}_{q_{\phi}} \log p_{\theta}(\mathbf{x}_i, \mathbf{Z}_i) + H(q_{\phi}).\end{aligned}$$

这不同于前面的 SVI 层次模型: 共享随机量 $\mathbf{u}$ 被积分掉以后, 各样本一般不独立, 不能把联合对数证据拆成逐样本对数证据之和; 其 ELBO 还包含全局因子的贡献。

在上述独立模型中, 令 $\mathcal{L}_i^{\star} = \sup_{\phi} \mathcal{L}_i(\phi)$; 设共享网络达到其最优参数

⁶ D. P. Kingma, M. Welling, *Auto-Encoding Variational Bayes* In arXiv preprint arXiv:1312.6114, 2013

ω^* , 实际训练结果为 $\hat{\omega}$ 。假设以下各目标值有限, 对同一批样本有

$$\begin{aligned}
 & \sum_i \log p_{\theta}(\mathbf{x}_i) - \sum_i \mathcal{L}_i(f_{\hat{\omega}}(\mathbf{x}_i)) \\
 &= \sum_i [\log p_{\theta}(\mathbf{x}_i) - \mathcal{L}_i^*] \\
 & \quad + \left[\sum_i \mathcal{L}_i^* - \sum_i \mathcal{L}_i(f_{\omega^*}(\mathbf{x}_i)) \right] \\
 & \quad + \left[\sum_i \mathcal{L}_i(f_{\omega^*}(\mathbf{x}_i)) - \sum_i \mathcal{L}_i(f_{\hat{\omega}}(\mathbf{x}_i)) \right].
 \end{aligned} \tag{22.18}$$

三项分别是近似族误差、共享映射限制带来的摊销误差和网络优化误差, 按定义均非负。若最优值未取得, 改用上确界解释。总体和的非负性不保证每个样本上的网络最优解都优于实际解; 训练还必须在同一固定模型下比较。关于近似与摊销两类误差的区分, 可参见 Cremer 等人的分析⁷。

这些误差描述的是对模型后验的逼近。若生成模型本身遗漏了现实中的因素, 即使后验推断精确, 预测也可能失准; 这种模型失配不能从式 (22.18) 直接读出。共享训练同时调整生成模型时, 后验与近似族还会相互适应, 因此不能把训练 ELBO 的全部改善都归因于推断更准确。

⁷ C. Cremer, X. Li, D. Duvenaud, *Inference Suboptimality in Variational Autoencoders* In Proceedings of the 35th International Conference on Machine Learning, 2018, pp. 1078–1086

22.2.4 从 Bethe 到 Kikuchi 局部自由能

结构化平均场把部分依赖保存在一个合法 q 中。另一种思路是不先构造全局 q , 而是直接维护节点和因子的局部概率表。以下设有限离散因子图的目标为 $p(\mathbf{z}) = Z^{-1} \prod_a \psi_a(\mathbf{z}_{S_a})$, 所有因子严格正, 每个变量至少邻接一个因子。观测已吸收到 ψ_a 中。令 $N(i)$ 为变量 i 的邻接因子集合, $d_i = |N(i)|$ 。树上的和积消息是

$$\begin{aligned}
 n_{i \rightarrow a}(z_i) &\propto \prod_{b \in N(i) \setminus \{a\}} m_{b \rightarrow i}(z_i), \\
 m_{a \rightarrow i}(z_i) &\propto \sum_{\mathbf{z}_{S_a \setminus \{i\}}} \psi_a(\mathbf{z}_{S_a}) \prod_{j \in S_a \setminus \{i\}} n_{j \rightarrow a}(z_j).
 \end{aligned} \tag{22.19}$$

树上去掉一条边会分离两个子图, 因此消息汇总的是互不重复的变量集合; 完整的双向传递可得精确边缘。在含环图上照用同一更新, 就是**环置信传播** (loopy belief propagation, LBP)。环使传回的信息可能已经受过当前节点的影响, 树上的独立分支解释随之失效。

算法从消息读出

$$b_i(z_i) \propto \prod_{a \in N(i)} m_{a \rightarrow i}(z_i), \quad b_a(\mathbf{z}_{S_a}) \propto \psi_a(\mathbf{z}_{S_a}) \prod_{i \in S_a} n_{i \rightarrow a}(z_i).$$

这些 b_i, b_a 称为**伪边缘** (pseudomarginal): 它们被当成边缘概率使用, 但

暂未保证存在一个共同的全局分布。将非负、归一化及

$$\sum_{\mathbf{z}_{S_a \setminus \{i\}}} b_a(\mathbf{z}_{S_a}) = b_i(z_i), \quad i \in S_a \quad (22.20)$$

组成的约束集合记为 $\mathcal{L}$ ，称为**局部多面体** (local polytope)。它只检查因子与节点是否一致，故 $\mathcal{M} \subseteq \mathcal{L}$ ；在含环图上包含关系可能严格。

局部表格如何组成熵？每个因子熵已经包含其中节点的熵，直接相加会重复计数。树结构恰好允许减掉多算的部分：

$$\begin{aligned} H_B(\mathbf{b}) &= \sum_a H(b_a) + \sum_i (1 - d_i) H(b_i), \\ F_B(\mathbf{b}) &:= - \sum_a \mathbb{E}_{b_a} \log \psi_a - H_B(\mathbf{b}). \end{aligned} \quad (22.21)$$

F_B 是**Bethe 自由能** (Bethe free energy)，即负的期望对数得分再减去局部熵近似。最小化自由能等价于最大化相应的得分加熵，但一般不等价于最大化某个合法 q 的 ELBO。

树上为何可以精确使用这个熵公式？对正的局部一致 $\mathbf{b}$ ，构造

$$q_T(\mathbf{z}) = \frac{\prod_a b_a(\mathbf{z}_{S_a})}{\prod_i b_i(z_i)^{d_i-1}}.$$

从叶端向内求和时，每次用局部一致性消去一个分支，最终得到 1；保留任一节点或因子而消去其余分支，就得到对应的 b_i 或 b_a 。对 $\log q_T$ 求期望给出 $H(q_T) = H_B(\mathbf{b})$ 。任何具有相同局部边缘的分布 q 都满足 $\mathbb{E}_q \log q_T = \mathbb{E}_{q_T} \log q_T$ ，于是 $\text{KL}(q \| q_T) = H_B(\mathbf{b}) - H(q) \geq 0$ 。因此 H_B 正是这些边缘下的最大熵， $\mathcal{L} = \mathcal{M}$ ，式 (22.5) 适用。含零边缘的树情形可由条件分布构造或取极限处理；含环图则不能重复这段消叶证明。

定理 22.3 正消息固定点与 Bethe 驻点 设有限因子图中的每个变量具有有限非空状态空间且至少邻接一个因子，每个因子 ψ_a 均取有限严格正值。令 $\mathcal{L}$ 为由非负性、归一化及式 (22.20) 定义的局部多面体， F_B 为式 (22.21) 定义的 Bethe 自由能。按任一固定正归一化约定，LBP 正消息固定点所产生的伪边缘是 F_B 在 $\mathcal{L}$ 相对内部的驻点。反之， $\mathcal{L}$ 中的每个正内部驻点都能由一组满足式 (22.19) 的正消息表示，消息的正比例缩放不影响伪边缘。

证明. 为约束 $\sum_{\mathbf{z}_{S_a \setminus \{i\}}} b_a - b_i = 0$ 引入乘子 $\lambda_{a,i}(z_i)$ ，另加归一化乘子。对 b_a 的驻点条件给出

$$b_a \propto \psi_a \prod_{i \in S_a} n_{i \rightarrow a}, \quad n_{i \rightarrow a} = e^{-\lambda_{a,i}}.$$

对 b_i 的驻点条件为 $(1 - d_i) \log b_i - \sum_a \lambda_{a,i} = \text{常数}$, 即 $\prod_a n_{i \rightarrow a} \propto b_i^{d_i-1}$ 。定义 $m_{a \rightarrow i}$ 为式 (22.19) 第二行的求和。局部一致性给出 $b_i \propto n_{i \rightarrow a} m_{a \rightarrow i}$ 。把它对 $a \in N(i)$ 相乘并使用前一乘积关系, 得到 $b_i \propto \prod_a m_{a \rightarrow i}$, 继而得到第一行消息方程。这一推导没有除以 $d_i - 1$, 因此也覆盖叶节点。

反过来, 固定点消息满足这两组乘积关系, 且由消息更新保证局部一致性。取 $\lambda_{a,i} = -\log n_{i \rightarrow a}$, 剩余与状态无关的常数由归一化乘子吸收, 即满足上述全部驻点条件。 ■

驻点可以是局部极小点、鞍点或退化点, 定理没有把迭代变成下降算法。一般含环图的 Bethe 熵不保证凹; LBP 可能振荡, 也可能随初值到达不同固定点。阻尼更新 $\log m^{\text{new}} \leftarrow (1 - \gamma) \log m^{\text{old}} + \gamma \log \tilde{m}$ 再归一化, 常用于减轻振荡, 但不构成普遍收敛保证。严格正性及内部条件也不能省略: 硬约束引入零概率后, 需要另外处理边界和不可定义的消息比值。固定点与自由能关系的原始论证见 Yedidia 等人⁸。

三角图提供了一个收敛却不精确的例子。均匀消息本身就是固定点, 给出 $b_i = (1/2, 1/2)$ 、 $b_{i,j}(0, 1) = b_{i,j}(1, 0) = 1/3$ 、 $b_{i,j}(0, 0) = b_{i,j}(1, 1) = 1/6$ 。边上不同值的概率 $2/3$ 不同于真实的 $8/13$ 。代入式 (22.21) 得到 $-F_B = 3 \log 3 = \log 27 > \log 26$, 所以它不是对数配分函数下界。

这个例子还能检验界方向。暂把 β 改为任意实数, 令 $r = e^\beta > 0$, 同一均匀固定点给出 $Z_B = (1 + r)^3$, 精确值是 $Z = 2 + 6r^2$, 二者相差 $(r - 1)^3$ 。当 $r = 2$ 时 Bethe 高估, 当 $r = 1/2$ 时 $Z_B = 27/8 < 7/2 = Z$, 则低估。节点边缘在两种情况下都仍然精确; 局部边缘、配分函数和联合依赖的误差不能混为一谈。

Bethe 近似把树上的精确熵分解延伸到含环图, 只需节点和原因子作用域上的伪边缘, 代价是短环约束可能丢失。三角图的问题不能靠更精确地归一化一条边解决, 因为缺失的是三条边共同闭合时的约束。Kikuchi 近似改变的是区域大小和重复计数方式: 直接维护覆盖一个短环的联合表格, 再协调重叠区域的边缘。**区域** (region) 在这里包含一组变量及分配给它的模型因子; 区域越大, 能同时检查的依赖就越多。

一种标准构造从覆盖全部原因子的最大区域出发, 加入所需非空交集, 形成按包含关系连接的有向无环区域图。用 R 表示区域的变量集合, b_R 是其归一化伪边缘。对父区域 R 及子区域 $S \subset R$ 要求 $\sum_{z_{R \setminus S}} b_R = b_S$ 。每个区域的**计数数** (counting number) c_R 纠正重叠造成的重复计数; 对按包含关系闭合的构造, 可递归设

$$c_R = 1 - \sum_{R' \supset R} c_{R'}. \quad (22.22)$$

需要检查每个原变量和每个原因子在包含它的区域中的计数总和均为 1,

⁸ J. S. Yedidia, W. T. Freeman, Y. Weiss, *Constructing Free Energy Approximations and Generalized Belief Propagation Algorithms* In IEEE Transactions on Information Theory, 2005, vol. 51, no. 7, pp. 2282–2312

并保证涉及同一变量或因子的区域通过相应包含边连通。任意选几块区域再任意给权重，并不能自动获得合法的区域近似。

令 $\Theta_R(\mathbf{z}_R) = \sum_{a: S_a \subseteq R} \log \psi_a(\mathbf{z}_{S_a})$ ，并假设上述因子计数条件成立，则

$$\begin{aligned} H_K(\mathbf{b}) &= \sum_R c_R H(b_R), \\ F_K(\mathbf{b}) &= \sum_R c_R \left[\sum_{\mathbf{z}_R} b_R(\mathbf{z}_R) \log b_R(\mathbf{z}_R) - \mathbb{E}_{b_R} \Theta_R \right]. \end{aligned} \quad (22.23)$$

这是 **Kikuchi 自由能** (Kikuchi free energy) 的一种区域表示。因子计数和区域一致性使能量项仍把每个原因子计算一次，近似发生在熵及全局一致性上。若不同因子作用域至多共享一个变量，Bethe 对应只用因子区域和单节点区域的特殊选择。一般因子图的 Bethe 仍属于区域自由能，但当因子共享多个变量时，未必等同于上述按全部交集闭合的 Kikuchi 构造。Kikuchi 可以覆盖短环并约束更大的联合表格，不是把同一组单节点消息换个名字。

例如，在 3×3 节点网格中选择四个小方格为最大区域，如图 22.3。四个方格各计 +1；两方格共享的四条内部边各计 -1；中央节点被四个方格及四条内部边共同覆盖，故还需计 $1 - 4 + 4 = +1$ 。边界交集的计数为 0，可以保留作一致性约束，也可在不改变约束含义时省去。相应熵为“四个方格熵之和，减四条内部边熵，再加中央节点熵”。若各节点独立且熵均为 h ，它给出 $4(4h) - 4(2h) + h = 9h$ ，恰好没有重复计算任何节点。这项检查只验证独立情形和计数正确，不证明相关分布下熵也精确。




图 22.3 方格区域近似的计数。浅色块表示四个四变量区域，粗线标出需减去的内部边，中央节点需再加一次。每条区域一致性约束都要求大表格向交集边缘化后与小表格相同；颜色之外还用区域面积、线条和节点区分三个层次。

自由能怎样产生区域消息？对约束 $\sum_{\mathbf{z}_{R \setminus S}} b_R - b_S = 0$ 引入乘子 $\lambda_{R,S}(\mathbf{z}_S)$ 。内部驻点满足

$$c_R(\log b_R - \Theta_R) = \sum_{P: P \rightarrow R} \lambda_{P,R} - \sum_{S: R \rightarrow S} \lambda_{R,S} + \text{常数}. \quad (22.24)$$

归一化项及 c_R 带来的常数已经合并。乘子是交集配置上的函数，因此指数化以后就是区域之间的消息。这一步同时说明为何不能把单节点消息不加修改地用于区域图：每条消息的索引现在是整个交集，且负计数区域会产生校正分母； $c_R = 0$ 时驻点方程是乘子之间的约束，不能除以 c_R 。

在标准父子区域参数化中，还能把消息方程写成可直接计算的形式。记 $\mathcal{D}(R)$ 为 R 及其全部后代， ∂R 为所有从 $\mathcal{D}(R)$ 外进入 $\mathcal{D}(R)$ 的有向区域边， $\Psi_R = e^{\Theta_R}$ 。伪边缘写为

$$b_R(\mathbf{z}_R) \propto \Psi_R(\mathbf{z}_R) \prod_{(P \rightarrow Q) \in \partial R} m_{P \rightarrow Q}(\mathbf{z}_Q).$$

这组乘子参数化将上式的计数校正纳入区域边的组合中。把它代入父子一致性并解出一条消息，得到更新方程

$$m_{R \rightarrow S}(\mathbf{z}_S) \propto \frac{\sum_{\mathbf{z}_{R \setminus S}} \Psi_R(\mathbf{z}_R) \prod_{(P \rightarrow Q) \in \partial R} m_{P \rightarrow Q}(\mathbf{z}_Q)}{\Psi_S(\mathbf{z}_S) \prod_{\substack{(P \rightarrow Q) \in \partial S \\ (P \rightarrow Q) \neq (R \rightarrow S)}} m_{P \rightarrow Q}(\mathbf{z}_Q)}. \quad (22.25)$$

同时出现在分子、分母且只依赖 $\mathbf{z}_S$ 的项可先约去。消息用正值初始化，每次在父区域求和、在交集上比较并归一化，然后继续更新其他区域。这就是**广义置信传播**（generalized belief propagation, GBP）的一种父子消息形式。区域图须满足前述覆盖、计数和连通条件；不同冗余约束与消息规范会给出不同但相关的更新式。其固定点关系与算法构造的完整论述仍见 Yedidia 等人，而不是从任意重叠集合都能推出这一参数化⁹。

对贯穿例子，只要把三变量三角形本身选为最大区域，就需维护 8 项的表格；区域自由能退化为整个联合分布的真实自由能，最优值恰为 $-\log 26$ 。这解释了区域扩张为什么可能改进短环问题，也显示了代价。若每个变量有 k 个状态，大小为 r 的区域需要 k^r 项，交集一致性还带来额外存储与通信。一般图上不断加入区域未必单调改善 Kikuchi 目标或每个边缘的误差，因为熵近似也随区域选择改变。除非区域构成满足运行交集性质的精确团树等特殊情形，否则仍不能保证全局一致、自由能凸或普通 GBP 迭代收敛。

区域扩张同时改变伪边缘及其一致性约束；另一条路线保持成对局部多面体不变，改用树分布构造可控的熵近似。记 $\rho_T > 0$ 为生成树 T 的权重， $\sum_T \rho_T = 1$ ，并令 $\rho_{i,j} = \sum_{T:(i,j) \in T} \rho_T$ 为边 (i,j) 的出现率。对成对模

⁹ J. S. Yedidia, W. T. Freeman, Y. Weiss, *Constructing Free Energy Approximations and Generalized Belief Propagation Algorithms* In IEEE Transactions on Information Theory, 2005, vol. 51, no. 7, pp. 2282–2312

型，正温度的**树重加权**（tree-reweighted, TRW）熵定义为

$$H_{\text{TRW}}(\mathbf{b}) = \sum_i H(b_i) - \sum_{(i,j) \in E} \rho_{i,j} I(b_{i,j}), \quad (22.26)$$

$$I(b_{i,j}) = \sum_{k,l} b_{i,j}(k,l) \log \frac{b_{i,j}(k,l)}{b_i(k)b_j(l)}.$$

这里 I 是两节点的互信息。每棵树的熵为 $\sum_i H(b_i) - \sum_{(i,j) \in T} I(b_{i,j})$ ，所以 H_{TRW} 是树熵的凸组合。对任意全局 q ，给定其树边缘的最大熵树分布的熵不小于 $H(q)$ ；逐树加权使得 $H(q) \leq H_{\text{TRW}}(\mathbf{b}(q))$ 。因此

$$A(\boldsymbol{\theta}) \leq \max_{\mathbf{b} \in \mathcal{L}} \{\langle \boldsymbol{\theta}, \mathbf{b} \rangle + H_{\text{TRW}}(\mathbf{b})\}. \quad (22.27)$$

树熵在树的局部一致边缘上是凹函数，可由根节点熵加沿树条件熵之和看出；其凸组合仍凹。因此这是凹目标的凸约束最大化。边出现率必须来自树分布，不能任意选正权重就宣称保有熵上界。关于配分函数上界的原始构造见 Wainwright 等人¹⁰。

Bethe 在成对图中相当于把每条边的互信息都减一次；有环图上这通常不是一个生成树分布的边出现率，所以没有上述熵上界论证。TRW 用于近似边缘时也不保证每个边缘比 Bethe 准确，上界约束的是最优目标值。它与 Kikuchi 分别通过树熵凸组合和更大区域修正含环图的局部自由能，不能只按区域大小排成必然改善的顺序。

¹⁰ M. J. Wainwright, T. S. Jaakkola, A. S. Willsky, *A New Class of Upper Bounds on the Log Partition Function* In IEEE Transactions on Information Theory, 2005, vol. 51, no. 7, pp. 2313–2335

22.2.5 拉普拉斯近似与期望传播

区域扩张主要处理依赖结构，另一些困难却来自连续后验的整体形状或单个因子的函数形式。拉普拉斯近似在一个众数附近使用整体曲率，期望传播则逐个放回难因子并匹配局部矩；两者都常产生高斯近似，却使用不同信息，也不是平均场或局部自由能路线的简单后继。

当保存完整密度会使每次更新越来越贵时，可以保留一个易计算的指数族，每次只把一个难因子暂时放回模型，计算它对重要矩的影响，再用近似族中的分布匹配这些矩。

设目标 $p(\mathbf{z}) \propto p_0(\mathbf{z}) \prod_a f_a(\mathbf{z})$ ，其中 p_0 容易处理，近似取 $q(\mathbf{z}) \propto p_0(\mathbf{z}) \prod_a \tilde{f}_a(\mathbf{z})$ 。站点 $\tilde{f}_a$ 是不必单独归一化的指数族因子。**期望传播** (ex-

pectation propagation, EP) 循环执行如下替换:

$$\begin{aligned}
 q^{\setminus a}(\mathbf{z}) &\propto q(\mathbf{z})/\tilde{f}_a(\mathbf{z}), \\
 \hat{p}_a(\mathbf{z}) &= \frac{f_a(\mathbf{z})q^{\setminus a}(\mathbf{z})}{Z_a}, \\
 q^{\text{new}} &= \arg \min_{q' \in \mathcal{Q}} \text{KL}(\hat{p}_a \| q'), \\
 \tilde{f}_a^{\text{new}}(\mathbf{z}) &\propto q^{\text{new}}(\mathbf{z})/q^{\setminus a}(\mathbf{z}).
 \end{aligned} \tag{22.28}$$

移除当前近似站点后的 $q^{\setminus a}$ 称为**空腔分布** (cavity distribution), 它避免同一因子被重复计算; 放回真实因子得到的 $\hat{p}_a$ 称为**倾斜分布** (tilted distribution)。这两者必须可归一化, 所匹配的矩必须存在。 Z_a 是这一步的归一化常数, 不是原模型的整体配分函数。第三行作为有限 KL 投影, 还要求倾斜分布与候选族的支持相容, 至少存在一个候选使 KL 有限, 且最小值能够在族中取得。

具体地, 设 $q'_\lambda = h \exp\{\langle \lambda, \mathbf{T} \rangle - A_q(\lambda)\}$ 具有固定支持, $\hat{p}_a$ 不在 $h = 0$ 处放置质量, $\mathbb{E}_{\hat{p}_a} \|\mathbf{T}\|_2 < \infty$ 。选取一个满足 $\text{KL}(\hat{p}_a \| q'_{\lambda_0}) < \infty$ 的候选, 便有

$$\begin{aligned}
 \text{KL}(\hat{p}_a \| q'_\lambda) &= \text{KL}(\hat{p}_a \| q'_{\lambda_0}) \\
 &\quad + A_q(\lambda) - A_q(\lambda_0) \\
 &\quad - \langle \lambda - \lambda_0, \mathbb{E}_{\hat{p}_a} \mathbf{T} \rangle.
 \end{aligned}$$

有限矩保证两个候选的对数密度比可积, 因而这里没有删去无穷常数。在自然参数域内部, 按式 (22.3) 对目标求导, 得到

$$\mathbb{E}_{q^{\text{new}}} \mathbf{T} = \mathbb{E}_{\hat{p}_a} \mathbf{T}. \tag{22.29}$$

在这些有限 KL 条件下, 投影才等价于矩匹配。若目标矩在正则最小指数族的内部均值域中, 严格凸性给出唯一的投影参数; 若落在边界, 可能只能取极限。若只知道矩存在且可实现, 式 (22.29) 仍可定义矩匹配更新, 但不能据此称它为唯一的有限 KL 投影: 全部候选的 KL 都可能为无穷大。矩不存在时, 这一矩匹配更新也无法定义。对高斯族, 充分统计量是 $\mathbf{z}$ 及 $\mathbf{z}\mathbf{z}^\top$, 故需匹配均值和协方差。

一维例子可完整算出一次更新。令 $p_0(z) = \mathcal{N}(z; 0, 1)$, 只有一个因子 $f(z) = \mathbb{I}[z \geq 0]$, 初始近似站点为 1。倾斜分布是半正态分布; 它与标准正态候选的 KL 为 $\log 2 < \infty$, 满足上述有限性条件。其归一化常数及矩为

$$Z_a = \frac{1}{2}, \quad \mathbb{E}_{\hat{p}_a} Z = \sqrt{\frac{2}{\pi}}, \quad \text{Var}_{\hat{p}_a}(Z) = 1 - \frac{2}{\pi}.$$

于是 $q^{\text{new}} = \mathcal{N}(m, v)$, $m \approx 0.797885$, $v \approx 0.363380$ 。若高斯自然参数写成 $\eta z - \tau z^2/2$, 新站点参数为 $\tau_a = v^{-1} - 1$, $\eta_a = m/v$ 。这一高斯仍对 $z < 0$

分配正概率；它匹配了两个矩，却没有保留硬支持。若反过来用该高斯近似最小化 $KL(q||p)$ ， KL 反而无穷大。这个例子直接说明了目标方向的差异。

EP 投影中的 $\hat{p}_a$ 依赖其他近似站点，故每一步并不是在最小化 $KL(p||q)$ 这个全局固定目标，更不是第 22.1 节的 ELBO 坐标上升。EP 固定点可以与特定自由能的驻点联系起来，但普通站点迭代不保证单调或收敛。高斯站点精度可以为负，不能强求每个站点自身是概率密度；然而总体 q 、每个被使用的空腔及倾斜分布必须合法。阻尼自然参数、检查协方差正定性和监测矩残差，是实际计算所需的保护。EP 的站点替换与矩匹配构造来自 Minka¹¹。

与逐因子修正的 EP 并行，若连续后验的主要质量集中在一个光滑峰附近，可以直接近似整个对数密度的局部形状。**拉普拉斯近似** (Laplace approximation) 在众数附近作二阶展开，用峰的位置和曲率决定一个高斯。令 $\ell(\mathbf{z}) = \log p(\mathbf{x}, \mathbf{z})$ ， $\hat{\mathbf{z}}$ 是内部严格局部极大点，且 $\mathbf{H} = -\nabla^2 \ell(\hat{\mathbf{z}})$ 正定，则

$$\begin{aligned}\ell(\mathbf{z}) &\approx \ell(\hat{\mathbf{z}}) - \frac{1}{2}(\mathbf{z} - \hat{\mathbf{z}})^\top \mathbf{H}(\mathbf{z} - \hat{\mathbf{z}}), \\ q_L(\mathbf{z}) &= \mathcal{N}(\hat{\mathbf{z}}, \mathbf{H}^{-1}), \\ p(\mathbf{x}) &\approx e^{\ell(\hat{\mathbf{z}})} (2\pi)^{d/2} |\mathbf{H}|^{-1/2}.\end{aligned}\tag{22.30}$$

线性项因众数处梯度为零而消失，高斯积分产生行列式项。计算上需要求众数、计算 Hessian，再用 Cholesky 分解求解线性系统及对数行列式，不必显式求逆。如果曲率存在零方向或负方向，这个高斯尚未定义；修改 Hessian 以强制正定已经改变近似，不能冒称原始二阶展开。

以 Gamma 密度 $p(z) \propto z^{a-1} e^{-bz}$ 、 $z > 0$ 为例，取 $a > 1, b > 0$ 。众数为 $\hat{z} = (a-1)/b$ ，负二阶导数为 $b^2/(a-1)$ ，故拉普拉斯近似为 $\mathcal{N}((a-1)/b, (a-1)/b^2)$ 。当 $a=3, b=1$ 时，它的均值、方差为 2, 2，而真实值为 3, 3，且高斯约有 7.865% 质量落在非法的负半轴。这里的偏差来自众数不等于均值、曲率不等于整体方差，以及二阶展开没有保留支持边界。

若改用 $y = \log z$ ，必须把 Jacobian 计入密度，得到 $p_Y(y) \propto \exp(ay - be^y)$ 。在 y 坐标中，众数为 $\log(a/b)$ 、近似方差为 $1/a$ ；变回 z 得到对数正态近似，保证正支持，却不等于直接在 z 坐标中得到的高斯。这说明拉普拉斯近似依赖参数化，不能把坐标变换视为无关紧要的数值技巧。

二阶展开是局部陈述，整体积分近似还需要主峰支配、尾部可控等条件。若 ℓ_n 随样本量 n 集中，唯一主峰附近的曲率按 n 增长，且高阶导数及尾部满足相应正则性，拉普拉斯法可形成渐近展开；仅仅存在一个正定 Hessian 并不推出任何有限样本误差保证。多峰时单个高斯遗漏其他峰，强偏斜或重尾时曲率也不能概括整体质量。多个峰的局部贡献可以相加，但须找到相关峰且避免错误重复计算。该方法既不天然最大化 ELBO，也不

¹¹ T. P. Minka, *Expectation Propagation for Approximate Bayesian Inference* In Proceedings of the Seventeenth Conference on Uncertainty in Artificial Intelligence, 2001, pp. 362–369

给出一般的证据上界或下界¹²。

¹² C. M. Bishop, *Pattern Recognition and Machine Learning*, Springer, 2006, 1st ed.

22.2.6 结果含义、收敛与诊断

相同的“近似后验”名称可能对应三种不同输出。平均场和结构化 VI 给出合法全局分布 q ，可以在 q 下计算联合事件，却受近似族限制；Bethe 和 Kikuchi 通常只给出彼此局部一致的伪边缘，不能默认拼成全局分布；拉普拉斯近似与高斯 EP 给出局部高斯或指数族近似，其支持、尾部和多峰结构可能与目标不同。诊断必须先确认输出对象，再判断它能回答哪些概率查询。

同样写成消息或参数迭代，算法的逻辑保证也可能完全不同。精确平均场坐标更新使 ELBO 单调且有界，所以目标值收敛；若还要证明迭代点趋向驻点，需要连续性、紧的水平集、坐标子问题解的适当唯一性等条件。近似族的联合目标一般非凹，坐标最优也未必全局最优。随机变分与随机梯度允许单步下降，通常分析的是噪声受控条件下的渐近驻点，而不是每步单调。

LBP 固定点存在也不等于 LBP 能到达它。对本章有限离散、严格正的情形，记 ψ_a 的最小、最大值为 $u_a > 0, v_a$ ， $k_i = |\mathcal{X}_i|$ 。对任意正输入，归一化后的因子到变量消息都满足 $m_{a \rightarrow i}(z_i) \geq u_a / (k_i v_a)$ ：求和中的其他消息乘积不依赖 z_i ，用 u_a 控制分子、用 $k_i v_a$ 控制归一化分母即可。把每条消息限制在具有这一正下界的概率单纯形内，所有消息组成的集合非空、紧且凸；将变量消息代入式 (22.19) 后，同步更新是这个集合上的连续自映射。由 Brouwer 不动点定理，它至少有固定点。不能直接在允许任意零消息的单形边界上使用同一论证，因为多条消息的乘积可能处处为零。

这项存在性论证不包含吸引力，迭代仍可能周期振荡。存在、可达、局部稳定及自由能极小，是四个不同的性质。若因子含零，正下界消失，上述存在性证明也不再适用。EP 同样只把固定点与局部矩匹配联系起来，拉普拉斯近似则依赖找到的众数和该点曲率；这些条件都不能推出边缘精度。

表 22.1 汇总了最容易混淆的对象。表中“无一般方向”不是说方法没有用，而是要求用边缘检查、残差或其他证据评价它，不能调用本不适用的下界定理。

方法与输出	优化或匹配对象	可用的界	不由此推出的结论
平均场、结构化 VI	合法 q 的期望得分与真实熵	ELBO 不高于对数证据	所有边缘及尾概率都准确
Bethe、Kikuchi	局部一致表与近似熵	一般没有统一上下界方向	固定点是全局最优或真实边缘
EP	倾斜分布的局部矩匹配	一般没有证据界方向	站点更新单调提高同一 ELBO
拉普拉斯近似	众数处对数密度的二阶展开	一般没有证据界方向	峰附近曲率控制整体分布误差
配分函数 TRW	树熵上界与局部多面体	优化值不低于对数配分函数	每个近似边缘都更准确
MPE 的 LP 与对偶	配置得分的线性松弛	对偶值不低于最大得分	分数解就是可行配置

表 22.1 各方法的目标与证书。分布近似的 ELBO 界针对对数证据；配置近似的 LP 界针对最大得分。二者虽可共享局部统计量，但不能互相替代。

近似不等于计算一定便宜。设有限离散成对图有 d 个节点、 m 条边，每节点至多 k 个状态。存储一般的稠密边势需 $O(mk^2)$ 。一次完全平均场扫描在直接计算全部边期望时通常需 $O(mk^2)$ ，变分边缘本身只需 $O(dk)$ 空间；Ising 等特殊代数结构可以更快。一次成对 LBP 扫描也通常需 $O(mk^2)$ ，但需要 $O(mk)$ 条目保存有向消息，若显式保存边伪边缘则另需 $O(mk^2)$ 。二者单轮量级相近，不表示迭代轮数或近似误差相近。

对于作用域 S_a 的稠密高阶因子，单次朴素局部求和本身就可能涉及 $k^{|S_a|}$ 个配置。变分消息传递只有在充分统计量期望有简洁计算时才能绕过这个规模，不能把指数族名称当作低复杂度证明。块变分若内部树宽为 w ，表格推断通常带有 k^{w+1} 因子；Kikuchi 最大区域有 r 个变量时，至少要面对 k^r 级区域表。区域方法的通信按交集状态数增长，增加区域既增加局部成本，也增加一致性校正工作。

SVI 将每次全数据局部计算从 n 个样本改为 b 个样本，代价约为 $bC_{\text{local}} + C_{\text{global}}$ ，其中两项分别是单样本局部更新和全局更新成本。若无需保留所有局部因子，还可避免 $O(n)$ 份局部状态存储；总训练成本仍取决于达到目标精度所需的小批量数。摊销推断把测试时的迭代换成网络前向成本，但训练、反向传播和模型存储并没有消失。两者可以结合，分别减少每次处理的数据量和每个样本的优化量。

连续近似的瓶颈常在矩阵运算。一个 d 维稠密高斯的协方差需要 $O(d^2)$ 空间，通用 Cholesky 分解需 $O(d^3)$ 时间；拉普拉斯近似与高斯 EP 都可能遇到它。稀疏精度、低秩更新、分块或对角表示能改变实际代价，但也可能改变近似族。EP 若每个站点作用于低维投影，可局部计算倾斜矩并利用低秩更新；不能把每次站点替换都机械地计为完整矩阵求逆。

分布近似应先问错在哪里。多峰目标可能被单峰 q 遗漏部分质量；强

相关目标可能被独立近似过度压缩；硬支持与 q 不匹配时，反向 KL 甚至没有有限值。三角例更提醒我们，所有单节点边缘正确也不能排除联合错误。诊断应覆盖实际要用的量，例如某个变量组合的概率、预测尾部或相关系数，而不只查看单一优化曲线。

对同一固定模型，精确 ELBO 的提高确实意味着反向 KL 下降，但不保证每一个统计量的误差都逐步下降。若能获知 $\varepsilon = \log p(\mathbf{x}) - \mathcal{L}(q)$ ，Pinsker 不等式给出 $\|q - p\|_{\text{TV}} \leq \sqrt{\varepsilon/2}$ ；对值域在 $[a, b]$ 内的函数 f ，有 $|\mathbb{E}_q f - \mathbb{E}_p f| \leq (b - a)\sqrt{\varepsilon/2}$ 。困难是对数证据通常未知，单看 ELBO 绝对值不能获得 ε ；方差等无界统计量也不能不加矩条件使用这个界。ELBO 的蒙特卡洛估计还会波动，估计值偶尔超过真实对数证据不等于理论下界失效。

可以利用重要性权重进行补充检查。若 $q(\mathbf{z}) > 0$ 覆盖 $p(\mathbf{x}, \mathbf{z}) > 0$ 的全部区域，独立采样 $\mathbf{z}^{(1)}, \dots, \mathbf{z}^{(K)} \sim q$ ，定义

$$w_k = \frac{p(\mathbf{x}, \mathbf{z}^{(k)})}{q(\mathbf{z}^{(k)})}, \quad \hat{Z}_K = \frac{1}{K} \sum_{k=1}^K w_k. \quad (22.31)$$

此时 $\mathbb{E} \hat{Z}_K = p(\mathbf{x})$ ，而 Jensen 不等式给出 $\mathbb{E} \log \hat{Z}_K \leq \log p(\mathbf{x})$ ，其中允许 $\log 0 = -\infty$ 。这是对采样重复取期望后的界，单次 $\log \hat{Z}_K$ 不是确定性下界。仅当 $\sum_k w_k > 0$ 时，后验期望才可用 $\sum_k w_k f(\mathbf{z}^{(k)}) / \sum_k w_k$ 作自归一化估计；该比值通常存在有限样本偏差，在适当可积条件下可一致。这里要求目标被 q 覆盖，与反向 KL 要求 q 避开目标零区域是不同方向的支持条件。

同样仅在 $\sum_k w_k > 0$ 时，才计算基于权重的**有效样本量** (effective sample size, ESS)

$$\widehat{\text{ESS}} = \frac{(\sum_k w_k)^2}{\sum_k w_k^2}.$$

它衡量本批权重是否集中在少数样本上，取值介于 1 与 K 之间。 K 个样本的权重相等且为正时，ESS 为 K ；只有一个权重非零时，ESS 为 1。例如实际抽了四次，权重为 $(9, 1, 0, 0)$ ，则 ESS 为 $10^2 / (9^2 + 1^2) = 100/82 \approx 1.22$ 。两个样本有非零权重，但主要贡献集中于其中一个，所以 ESS 接近 1，并不是在数非零权重的个数。

支持覆盖并不排除全零批次：以前面的半正态例为目标，取未归一化密度 $\mathcal{N}(\mathbf{z}; 0, 1)\mathbb{I}[\mathbf{z} \geq 0]$ 和标准正态提议，则 $w_k = \mathbb{I}[\mathbf{z}^{(k)} \geq 0]$ ，全零概率为 2^{-K} 。这时 $\hat{Z}_K = 0$ 仍是证据估计的一次结果，但自归一化比值和 ESS 均无定义，应报告“无有效加权样本”。应检查提议分布的覆盖和重叠程度，并用对数权重排查数值下溢，再考虑增加采样量；不能把全零权重改成均匀权重。

若权重极不均衡，ESS 会很小，提示 q 与目标不匹配或样本数不足。但全部样本都没有到达遗漏模态时，权重可能看起来很平稳，ESS 也不能发现尚未看见的质量。因此它是权重集中的诊断量，不是任意后验统计量的

精度保证。若权重二阶矩不存在，常规标准误差更不可靠。多初值比较、小规模精确枚举、较丰富近似族，以及第 23 章的采样诊断，可以提供互补证据。

另一个入口是**后验预测检查** (posterior predictive check)：从近似后验抽取潜变量或参数，再从观测模型生成复制数据，比较复制数据与实际数据的有意义统计量。它能揭示当前模型加推断流程未能复现的结构，却不能单独区分模型失配和推断误差。可在小问题上换成精确推断，或对同一模型比较不同推断方法，帮助定位来源；这些检查的目的不是用一条预测曲线代替所有后验校准问题¹³。

¹³ K. P. Murphy, *Machine Learning: A Probabilistic Perspective*, MIT Press, 2012

22.3 近似 MPE

22.3.1 从整数规划到局部多面体松弛

前面的输出是分布、伪边缘或局部高斯近似。现在改变查询：给定证据，要选出全部非证据变量的一组联合最优配置。本节的 MPE 严格沿用第 20.3.1 节的定义，只包含纯最大化任务。一般边缘 MAP 含有求和变量，其目标为 $\max_{\mathbf{z}_Q} \log \sum_{\mathbf{z}_R} \exp S(\mathbf{z}_Q, \mathbf{z}_R)$ ，明确不在本节范围内；求和与最大化的区别及正确消元顺序见第 20.3.2 节。以下 LP 不能把 $\mathbf{z}_R$ 也改成最大化后直接套用，否则查询已经被换成 MPE。

设所有变量有限离散，证据吸收后的对数得分为

$$S(\mathbf{z}) = \sum_i \theta_i(z_i) + \sum_a \theta_a(\mathbf{z}_{S_a}), \quad M = \max_{\mathbf{z} \in D} S(\mathbf{z}). \quad (22.32)$$

这里的得分暂不含 $-\log Z$ ；它不影响最优配置。先假设得分有限且至少有一个可行配置；硬约束可通过删除禁止状态或增加约束表达，不应把 $-\infty$ 当普通 LP 系数输入求解器。

为把配置写成线性变量，对每个节点状态 $k \in \mathcal{X}_i$ 引入 $\delta_i(k) \in \{0, 1\}$ ，对每个因子配置 $\mathbf{s} \in \mathcal{X}_{S_a}$ 引入 $\delta_a(\mathbf{s}) \in \{0, 1\}$ 。要求

$$\begin{aligned} \sum_{k \in \mathcal{X}_i} \delta_i(k) &= 1, & \sum_{\mathbf{s} \in \mathcal{X}_{S_a}} \delta_a(\mathbf{s}) &= 1, \\ \sum_{\mathbf{s}: s_i=k} \delta_a(\mathbf{s}) &= \delta_i(k), & i &\in S_a. \end{aligned} \quad (22.33)$$

每个节点恰选一个标签，每个因子恰选一个与其节点标签相容的配置。最大化

$$\sum_{i,k} \theta_i(k) \delta_i(k) + \sum_{a,\mathbf{s}} \theta_a(\mathbf{s}) \delta_a(\mathbf{s}) = \langle \theta, \delta \rangle$$

就得到**整数线性规划** (integer linear programming, ILP) 表示。给定 $\mathbf{z}$ 可唯一构造这些指示变量；反过来，节点的唯一标签及一致性迫使每个因子

也选中对应配置。这证明了整数可行解与原配置一一对应，而不只是两者目标看起来相似。

由于 $\mathcal{M}$ 是全部配置指示向量的凸包，

$$M = \max_{\mu \in \mathcal{M}} \langle \theta, \mu \rangle. \quad (22.34)$$

证明只需观察：凸组合的得分是配置得分的加权平均，不会高于最大配置得分，而最优配置本身就在凸包里。因此精确 MPE 也能写成连续线性优化，困难转移到了 $\mathcal{M}$ 的描述，而不是凭空消失。

丢掉二值要求，只保留 $\mu_i, \mu_a \geq 0$ 及式 (22.33) 中的线性等式，就得到局部多面体 $\mathcal{L}$ 上的**线性规划松弛** (linear programming relaxation, LP relaxation)：

$$U_{\text{LP}} = \max_{\mu \in \mathcal{L}} \langle \theta, \mu \rangle, \quad S(\hat{\mathbf{z}}) \leq M \leq U_{\text{LP}}. \quad (22.35)$$

左侧要求 $\hat{\mathbf{z}}$ 是真实可行配置，右侧来自 $\mathcal{M} \subseteq \mathcal{L}$ 。若求得的 LP 最优解为整数，它就是全局最优配置；若为分数，只能说得到了上界及伪边缘。LP 迭代中任意一个尚未最优的原始可行分数解，其目标不一定高于 M ；实际可随时报告的上界应来自 LP 对偶可行解，或已获证的 LP 最优值。

这与第 22.2.5 节的两种分布近似不同：LP 保留原配置得分，放宽的是可行域，没有对数密度二阶展开，也没有倾斜矩匹配。其上界来自集合包含关系；它既不是含熵自由能的下界，也不提供后验不确定性。

三角图中，取 $\mu_i(0) = \mu_i(1) = 1/2$ ，每条边 $\mu_{i,j}(0,1) = \mu_{i,j}(1,0) = 1/2$ ，其余为 0。这是图 22.2 右侧的局部一致点，得分为 3β ，且每条边的期望奖励至多为 β ，故 $U_{\text{LP}} = 3\beta$ 。真实最优值只有 $M = 2\beta$ 。这个点要求三个二元变量两两不同，无法实现；其分数值不代表额外的合法配置。增加三角不等式 $\sum_{(i,j) \in E} \Pr(Z_i \neq Z_j) \leq 2$ 即可把本例的最优值压回 2β ，但一般图需要哪些更高阶约束，仍是计算问题。

配置优化也可看成熵消失的极限。对 $\tau > 0$ ，有限状态空间上

$$\max_{\mathbf{z}} S(\mathbf{z}) \leq \tau \log \sum_{\mathbf{z}} e^{S(\mathbf{z})/\tau} \leq \max_{\mathbf{z}} S(\mathbf{z}) + \tau \log |D|.$$

左侧取最大的一项，右侧把每一项都用最大项控制，故 $\tau \downarrow 0$ 时夹逼到 M 。由熵对偶，中间量等于 $\max_{\mu \in \mathcal{M}} \{\langle \theta, \mu \rangle + \tau H^*(\mu)\}$ 。这说明分布推断与配置推断为何共享几何工具，也说明两者并非同一个查询：正温度下要计入全部配置的质量，零温度下只关心最大值。

22.3.2 从整体优化到对偶分解

LP 变量可能很多，直接交给通用求解器未必最方便。局部因子本来各自容易优化，困难是它们对共享变量必须作相同选择。**对偶分解** (dual decomposition) 暂时允许各个子问题保有共享变量的副本，再用乘子调整各副本的得分，使它们逐渐协调。

一个能直接核验的分解将每个节点和每个因子作为子问题。对因子 a 与节点 $i \in S_a$ 引入状态相关乘子 $\lambda_{a,i}(k)$ ，定义

$$D(\lambda) = \sum_i \max_{k \in \mathcal{X}_i} \left[\theta_i(k) + \sum_{a: i \in S_a} \lambda_{a,i}(k) \right] + \sum_a \max_{s \in \mathcal{X}_{S_a}} \left[\theta_a(s) - \sum_{i \in S_a} \lambda_{a,i}(s_i) \right]. \quad (22.36)$$

对任意共同配置，把同一 z_i 代入所有副本，乘子逐项抵消，子问题得分之和等于 $S(z)$ ；各子问题独立取最大只会提高这个和。因此 $D(\lambda) \geq M$ 对任意有限乘子成立。 D 是仿射函数的最大值之和，故凸，目标是最小化这个上界。

设节点子问题选出 k_i^* ，因子子问题选出 s_a^* ，则

$$g_{a,i}(k) = \mathbb{I}[k_i^* = k] - \mathbb{I}[s_{a,i}^* = k]$$

是一个次梯度，更新 $\lambda_{a,i}^{(t+1)}(k) = \lambda_{a,i}^{(t)}(k) - \eta_t g_{a,i}(k)$ 。若节点选择了 k 而因子没有，更新降低节点对 k 的奖励，同时提高该因子对 k 的奖励，促使分歧缩小。平局时可选择任一最优配置，或在最优指示向量之间取凸组合。次梯度法单步不保证上界下降，实际应保留历次最小的 D ；也可使用有针对性的块坐标或平滑方法。

这个对偶究竟对应哪一个原问题？对局部 LP 的一致性等式引入同样的乘子，保留各节点、因子自己的概率单纯形约束。对每个单纯形最大化线性函数，恰好得到式 (22.36) 中的一个最大值。有限、非空且有界的 LP 满足强对偶，因而

$$\min_{\lambda} D(\lambda) = U_{LP} \geq M. \quad (22.37)$$

强对偶消除的是 LP 与其对偶之间的间隙，不是 LP 与整数问题之间的间隙。若全部子问题有一个共同的最优配置，代入便同时达到 D ，于是获得精确 MPE 证书；若没有协调成功，则需另外构造可行配置作为下界。三角例中零乘子已经给出 $D = 3\beta = U_{LP}$ ，继续优化乘子不能消除 β 的整数松弛间隙。

22.3.3 树重加权上界

单因子分解以节点和因子为子问题；树分解则把多条边组合成仍可精确求解的子问题，改变上界的计算与协调方式。以下限于成对模型，且先假设原图连通；不连通时可分别处理各连通分量。令 T 遍历覆盖原图边的若干生成树，权重 $\rho_T > 0$ 满足 $\sum_T \rho_T = 1$ 。在各树上选取得分参数 θ^T ，树外边的参数为 0，并要求 $\theta = \sum_T \rho_T \theta^T$ 。这里分解的是得分参数，不是把后验写成普通混合分布。于是

$$M \leq U_{\text{TRW}} := \sum_T \rho_T \max_{\mathbf{z}} \langle \theta^T, \mathbf{T}(\mathbf{z}) \rangle. \quad (22.38)$$

每棵树可用最大和消息及回溯求解，乘子在树间重新分配共享项而保持加权参数和不变。**树重加权** (tree-reweighted, TRW) 消息传递利用这种加权树分解构造和优化上界。

式 (22.38) 对任何固定参数分解都成立，但固定分解给出的 U_{TRW} 可能高于 U_{LP} ，因而比局部 LP 上界更松。若树族覆盖原图全部边，并在 $\sum_T \rho_T \theta^T = \theta$ 下对所有树参数分解最小化，则树对偶施加的正是节点与边的局部一致性约束，从而

$$\inf_{\{\theta^T\}} U_{\text{TRW}} = U_{\text{LP}}.$$

因此，优化后的标准树对偶是成对局部 LP 的一种分解求解方式，不是必然更强的松弛。要把上界压到 U_{LP} 以下，必须加入环或高阶一致性等更强约束，或引入能够施加这些约束的更大子问题；仅固定一组树或改变树权重并不能保证收紧松弛。

第 22.2 节的正温度 TRW 也能说明这一关系。把式 (22.27) 中的熵乘以 τ 并令 $\tau \downarrow 0$ ，局部集合上有界的熵项消失，得到 U_{LP} ，而不必得到整数最优值 M 。零温度 TRW 保留的是 LP 松弛及其 MPE 上界，不再近似后验边缘。

引理 22.4 树一致的最优性证书 设 D 为有限非空配置集， $\mathfrak{T}$ 为有限树子问题集合，且 $\rho_T > 0$ 、 $\sum_{T \in \mathfrak{T}} \rho_T = 1$ 。每个树得分 $S_T : D \rightarrow \mathbb{R}$ 均取有限值，并满足原问题得分分解 $S(\mathbf{z}) = \sum_{T \in \mathfrak{T}} \rho_T S_T(\mathbf{z})$ 。令

$$M = \max_{\mathbf{z} \in D} S(\mathbf{z}), \quad U_{\text{TRW}} = \sum_{T \in \mathfrak{T}} \rho_T \max_{\mathbf{z} \in D} S_T(\mathbf{z}).$$

则 $U_{\text{TRW}} = M$ 当且仅当所有树子问题具有一个共同最优配置。

证明. 若 $\mathbf{z}^*$ 同时在每棵树上最优，则加权求和得到 $U_{\text{TRW}} = S(\mathbf{z}^*) \leq M$,

与上界合并即得等号。反之，取原问题的最优配置 $\hat{\mathbf{z}}$ ，则

$$U_{\text{TRW}} - M = \sum_T \rho_T \left[\max_{\mathbf{z}} S_T(\mathbf{z}) - S_T(\hat{\mathbf{z}}) \right].$$

每个方括号非负且每个 $\rho_T > 0$ 。总和为零迫使每项为零，所以 $\hat{\mathbf{z}}$ 在每棵树上都最优。 ■

共同最优要求存在同一完整配置，不能仅看各节点最大边缘的候选标签集合是否相交；存在平局时，局部兼容选择还需要整体回溯。三角图有三棵生成树，各取权重 $1/3$ ，每条边出现概率为 $2/3$ 。将出现的边参数放大为 $3\beta/2$ 后，加权和恢复原参数。每棵树都能使两条边不同，最优得分为 3β ；但三个树问题没有共同最优配置，所以其上界 3β 不紧。TRW 的最优性证书及其与 LP 的关系见 Wainwright 等人¹⁴。

22.3.4 图割与可精确求解的特殊情形

松弛并非总会产生无法实现的最优值。有些能量结构允许直接返回整数最优配置。为说明图割，以下改用最小化能量 $E(\mathbf{z}) = -S(\mathbf{z})$ ；从这一处起，上界和下界的方向随符号翻转。设 $z_i \in \{0, 1\}$ ， $E(\mathbf{z}) = \sum_i D_i(z_i) + \sum_{(i,j) \in E} V_{i,j}(z_i, z_j)$ ，其中 D_i 和 $V_{i,j}$ 分别为一元代价和成对代价。二元成对项满足

$$V_{i,j}(0, 0) + V_{i,j}(1, 1) \leq V_{i,j}(0, 1) + V_{i,j}(1, 0) \quad (22.39)$$

时称为**次模** (submodular)。这一不等式限制的是四项的相对组合，不要求两个相同标签的能量都小于两个不同标签的能量。

定理 22.5 二元成对次模能量的图割表示 设 $\mathcal{G} = (V, E)$ 为有限无向图， $z_i \in \{0, 1\}$ ，且

$$E(\mathbf{z}) = \sum_{i \in V} D_i(z_i) + \sum_{\{i,j\} \in E} V_{i,j}(z_i, z_j),$$

其中所有一元项与成对项均取有限实数。若每个成对项都满足式 (22.39)，则能量最小化可转化为非负容量网络上的 s - t 最小割，最小割给出一个全局最优二元配置。

证明. 对一条边暂记 $v_{k,l} = V_{i,j}(k, l)$ ，定义

$$w_{i,j} = \frac{v_{0,1} + v_{1,0} - v_{0,0} - v_{1,1}}{2} \geq 0.$$

逐项代入四种配置可验证

$$V_{i,j}(z_i, z_j) = v_{0,0} + a_{i,j}z_i + b_{i,j}z_j + w_{i,j}|z_i - z_j|,$$

¹⁴ M. J. Wainwright, T. S. Jaakkola, A. S. Willsky, *MAP Estimation via Agreement on Trees: Message-Passing and Linear Programming* In IEEE Transactions on Information Theory, 2005, vol. 51, no. 11, pp. 3697–3717

其中 $a_{i,j} = v_{1,0} - v_{0,0} - w_{i,j}$ 、 $b_{i,j} = v_{0,1} - v_{0,0} - w_{i,j}$ 。把线性项并入节点一元项，得到 $E = C + \sum_i D'_i(z_i) + \sum_{(i,j)} w_{i,j} |z_i - z_j|$ 。从每个 D'_i 减去 $\min_k D'_i(k)$ ，把减掉的量加到 C ，即可令终端容量非负。

为每个变量建立节点，规定源点 s 一侧表示 $z_i = 0$ ，汇点 t 一侧表示 $z_i = 1$ 。边 $s \rightarrow i$ 容量取 $D'_i(1)$ ，边 $i \rightarrow t$ 容量取 $D'_i(0)$ ；每对相邻变量连容量为 $w_{i,j}$ 的无向边，或等价的双向有向边。一次割恰好支付所选一元项及每条跨割边的 $w_{i,j}$ ，所以割容量等于 $E - C$ 。所有二元配置都对应一个割，反之亦然，最小割因而给出全局最小能量。■

这一定理只讨论二元成对能量和给定标签编码。负的 $w_{i,j}$ 不能当作合法容量；高阶因子也不由这个四项判据自动处理。图表示的更一般条件与必要性结果见 Kolmogorov 和 Zabih¹⁵。

一个最小网络即可检查终端方向。取 $D_1 = (0, 2)$ 、 $D_2 = (2, 0)$ 、 $w_{1,2} = 1$ ，则 $(0, 0)$ 、 $(0, 1)$ 、 $(1, 0)$ 、 $(1, 1)$ 的能量依次为 2, 1, 5, 2。图 22.4 中最小割把节点 1 留在源侧、节点 2 放在汇侧，只支付中间容量 1，得到最优配置 $(0, 1)$ 。这里图割不仅报告数值，还直接报告合法标签。

¹⁵ V. Kolmogorov, R. Zabih, *What Energy Functions Can Be Minimized via Graph Cuts?* In IEEE Transactions on Pattern Analysis and Machine Intelligence, 2004, vol. 26, no. 2, pp. 147–159




图 22.4 两变量次模能量的 s - t 割网络。实线终端边容量为 2，点线终端边容量为 0，中间无向边容量为 1。虚线表示分开 $\{s, 1\}$ 和 $\{2, t\}$ 的割，容量为 1，对应配置 $(0, 1)$ 。

22.3.5 紧性、取整与最优性诊断

这类能量的局部 LP 松弛为何也紧，可以直接证明而不依赖求解器。令 $m_i = \mu_i(1)$ 。对任何局部一致的边表， $\Pr(Z_i \neq Z_j) \geq |m_i - m_j|$ ，因为 $m_i - m_j = \mu_{i,j}(1, 0) - \mu_{i,j}(0, 1)$ 。非负 $w_{i,j}$ 使松弛能量不小于

$$C + \sum_i [(1 - m_i)D'_i(0) + m_i D'_i(1)] + \sum_{(i,j)} w_{i,j} |m_i - m_j|.$$

令所有节点共用 $U \sim \text{Uniform}(0, 1)$ ，取 $z_i = \mathbb{I}[U < m_i]$ ，则节点均值为 m_i ，不同值概率恰为 $|m_i - m_j|$ 。这个全局分布的期望能量等于上式，所以至少有一个阈值配置的能量不高于原 LP 解。用于 LP 最优解时，结合松弛下界

便得到整数最优值等于 LP 最优值。这证明存在整数最优解，但不保证求解器在存在平局时不会返回若干整数最优解的分数混合。按排序后的 m_i 检查至多 $d + 1$ 个阈值区间即可寻找相应配置。

树上的局部 LP 也总是紧，因为局部一致表可以构造全局树分布，线性得分的期望不超过某个配置的得分。这里“紧”指最优值相等并存在整数最优解，不意味着树上每个合法边缘都是整数。含环图上的紧性则依赖结构、势函数及参数，不能仅从消息收敛判断。

对多标签变量，一次 s - t 割只能表达两个选项。 α 扩展 (α -expansion) 固定当前标签 ℓ_i ，让每个节点选择保留 ℓ_i 或改为 α ，把这一步化为二元问题。若成对项为 $w_{i,j}d(k, l)$ ， $w_{i,j} \geq 0$ 且 d 是标签上的度量，三角不等式给出

$$d(\ell_i, \ell_j) + d(\alpha, \alpha) \leq d(\ell_i, \alpha) + d(\alpha, \ell_j).$$

所以每个扩展子问题次模，能精确求解。循环标签并只接受严格改善，有限状态下会停在对所有扩展动作都无法改进的配置，但未必是全局最优。

α - β 交换只让当前标为这两个标签的节点互换，可处理某些不满足三角不等式的非负对称成对代价。对于非负一元项、非负边权的 Potts 能量，完全达到扩展局部最优的配置有不超过全局最优能量两倍的经典保证；这一结论依赖能量形式和停止条件，不能把它推广成任意度量、任意初次扩展或任意加常数后的能量都具有同一比值。更一般的扩展、交换与近似比结果参见 Boykov 等人¹⁶。

有序标签和特定凸相邻代价可用多层图构造精确求解，但一般多标签或非次模能量没有这样的通用保证。某些非次模二次伪布尔松弛只能固定部分变量，其余变量还需补全；不能把“部分标签有保证”当作完整最优配置。更一般的 LP 分数解可以逐点选最大伪边缘、联合取整、局部搜索，或加入切平面、分支定界。逐点取整会丢失协调，硬约束存在时还可能不可行，因此必须回到原目标和原约束复核。

对得分最大化，保留已找到的最好可行值 $L = S(\hat{\mathbf{z}})$ 及一个经验证的对偶上界 U ，则

$$0 \leq M - S(\hat{\mathbf{z}}) \leq U - S(\hat{\mathbf{z}}). \quad (22.40)$$

右侧是可计算的原始-对偶间隙 (primal-dual gap)，在此处比较整数可行解与松弛对偶证书。若把 LP 原始值也记下来，还能区分求解器尚未收敛的差距和取整后的损失。对能量最小化，方向反过来：松弛或对偶提供下界，可行配置提供上界。在三角例中，逐点按平局选 0 得到得分 0；把任一变量翻转便达到 2β ，但 LP 上界仍为 3β 。局部改进修复了取整损失，却没有修复松弛间隙。

对偶 LP 优化的全局最优性来自凸性及正确求解，而不是因为消息看上去像置信传播。即便 D 已收敛到 U_{LP} ，仍可能没有共同整数配置。反过来，

¹⁶ Y. Boykov, O. Veksler, R. Zabih, *Fast Approximate Energy Minimization via Graph Cuts* In IEEE Transactions on Pattern Analysis and Machine Intelligence, 2001, vol. 23, no. 11, pp. 1222–1239

一旦找到可行配置并达到对偶值，就有全局证书，不必等待参数或消息达到某种唯一极限。TRW 消息的具体调度也必须单独分析；具有凸的上界目标，不意味着任意形式的消息更新都单调优化该目标。

MPE 分解把计算分配给子问题。成对树上的一次最大和及回溯需 $O(|E_T|k^2)$ ；多棵树可并行，但共享乘子的协调和通信仍在。显式局部 LP 有约 $O(dk + mk^2)$ 个变量，其求解时间不只由变量数决定，还受求解器、约束和容差影响。图割属于多项式时间的特殊精确子问题，一次扩展只解一个二元动作，整体还要计入标签轮数。衡量可扩展性时，应同时报告单轮计算、存储、通信和达到所需诊断标准的轮数。

MPE 近似需要另一套记录：原约束是否满足、可行配置得分是多少、对偶上界是多少，以及它们的差距。三角图的结论可同时列出：完全平均场的对数配分函数下界为 3.119162，结构化固定点的同类下界为 3.178054，精确 $\log Z_\beta = 3.258097$ ，Bethe 固定点的对数配分函数近似为 3.295837。MPE 方面，最好可行得分为 $2 \log 2 = 1.386294$ ，LP 与该树分解的上界为 $3 \log 2 = 2.079442$ 。两个数列不能放到同一条“下界改善”曲线上比较，因为所约束的真值不同。

若原始-对偶间隙很小，就能控制当前配置距离最优得分的损失；它不说明后验是否集中在该配置附近，也不提供边缘概率。若间隙较大，则应继续优化对偶、改善取整、增加一致性约束，或接受一个明确量化的误差范围。报告连续松弛最优值而不报告合法配置，尚未完成配置推断任务。

22.4 本章小结

把推断改写为优化，改变的是保留哪些概率关系以及接受哪种误差。对于后验分布，ELBO 把近似程度连接到反向 KL；平均场和结构化近似以合法全局分布换取可计算的期望与熵。共轭、随机更新和摊销映射分别降低局部代数、数据遍历与重复优化的成本，却不会修复近似族限制。

局部自由能直接维护伪边缘。树上的一致性与熵分解是精确的，推广到含环图后才出现 Bethe 与 Kikuchi 近似；更大区域能检查更多关系，也会增加表格代价。EP 匹配临时放回真实因子后的矩，拉普拉斯近似匹配峰附近的曲率，二者保留的信息不同。固定点、局部匹配和目标改善，都须与真实边缘及尾部误差区分。

查询为全部非证据变量的 MPE 时，熵不参与目标，边缘多面体上的线性优化等价于选择最优配置。局部多面体给出最大得分上界，对偶分解与 TRW 提供证书，图割在二元的模等条件下直接返回整数最优解；这些结论不能越过边缘 MAP 中的求和运算。分布近似检查支持、相关性与预测，配置近似检查可行性、取整和原始-对偶间隙，两类诊断不能互相替代。

基于采样的近似推断

设备发出报警以后，故障的后验概率是多少？第 20 章通过精确消元回答了这个问题；中间因子或积分过于复杂时，第 22 章改为优化一个可计算的近似分布。本章研究另一种近似表示：生成一组能够代表后验的样本，用样本中故障出现的比例估计所求概率。这里真正困难的并不是生成随机数，而是让随机数经过适当的变换和筛选，覆盖我们关心的分布。

本章按样本产生机制组织这一思路。能直接生成独立样本时，误差由普通样本均值的理论控制；只能从另一个分布采样时，需要用权重修正分布差异；只能在已有状态附近更新时，需要构造保持目标分布的 Markov 转移；观测连续到达时，则要把样本及其权重一起递推。不同机制提供不同的正确性保证，也带来不同的失效方式。我们既要知道估计量在什么条件下趋近答案，也要知道有限计算下哪些迹象足以让人怀疑答案。

23.1 采样推断的定义

设观测为 $\mathbf{x}$ ，潜变量为 $\mathbf{z}$ ，固定模型参数并省略其记号。把目标后验写为

$$\begin{aligned} p(\mathbf{z} | \mathbf{x}) &= \frac{\gamma(\mathbf{z})}{Z_{\mathbf{x}}}, & \gamma(\mathbf{z}) &= p(\mathbf{x}, \mathbf{z}), \\ Z_{\mathbf{x}} &= \int \gamma(\mathbf{z}) d\mathbf{z}, & I_h &= \mathbb{E}_{p(\mathbf{z}|\mathbf{x})}[h(\mathbf{z})]. \end{aligned} \quad (23.1)$$

其中 $0 < Z_{\mathbf{x}} < \infty$ ， h 是待求期望的实值函数。本章的积分也涵盖离散情形，此时改为求和， p 表示概率质量而非密度。 γ 可以计算到一个与 $\mathbf{z}$ 无关的正比例常数；这足以计算后验期望，却不足以确定原模型的证据 $Z_{\mathbf{x}}$ 。估计证据时，必须知道 γ 的实际尺度。

蒙特卡洛估计 (Monte Carlo estimation) 用随机样本形成积分的数值近似。若 $\mathbf{z}_1, \dots, \mathbf{z}_n$ 独立同分布地来自目标后验，则

$$\hat{I}_{h,n} = \frac{1}{n} \sum_{i=1}^n h(\mathbf{z}_i). \quad (23.2)$$

选择 $h(\mathbf{z}) = \mathbb{I}\{\mathbf{z} \in B\}$, 即事件 B 发生时取 1、否则取 0 的指示函数, 就得到后验事件概率的估计; 选择某个分量或分量乘积, 则得到均值或二阶矩。由一批样本可以计算多个查询, 但不同查询的误差未必相同。

若 $\mathbb{E}_p|h| < \infty$, 大数定律保证 $\hat{I}_{h,n} \rightarrow I_h$ 几乎必然成立, 这称为估计的**一致性** (consistency): 样本数增加时, 估计趋向正确答案。若另有 $\sigma_h^2 = \text{Var}_p(h) < \infty$, 独立性消去不同样本之间的协方差, 因而

$$\begin{aligned} \mathbb{E}[\hat{I}_{h,n}] &= I_h, & \text{Var}(\hat{I}_{h,n}) &= \frac{\sigma_h^2}{n}, \\ \sqrt{n}(\hat{I}_{h,n} - I_h) &\xrightarrow{d} \mathcal{N}(0, \sigma_h^2). \end{aligned} \quad (23.3)$$

最后一行是中心极限定理, 箭头表示依分布收敛。**蒙特卡洛标准误** (Monte Carlo standard error, MCSE) 衡量重复运行估计过程时答案的波动; 独立样本下可用 $s_h/\sqrt{n}$ 估计, 其中 s_h^2 是 $h(\mathbf{z}_i)$ 的样本方差。它不是后验标准差: 后验标准差描述模型中的不确定性, MCSE 描述计算尚未精确到什么程度。把 MCSE 减半通常需要四倍样本, 而不是两倍。

示例 23.1 报警后的故障概率 沿用人工构造的设备模型 $F \rightarrow H \rightarrow A \leftarrow S$: F 表示故障, H 表示过热, A 表示报警, S 表示传感器失灵。根节点 F, S 独立, 且

$$\begin{aligned} p(F=1) &= 0.1, & p(S=1) &= 0.05, \\ p(H=1 | F=1) &= 0.8, & p(H=1 | F=0) &= 0.1. \end{aligned}$$

报警条件表仍与前面的精确推断相同:

(h, s)	(0, 0)	(1, 0)	(0, 1)	(1, 1)
$p(A=1 h, s)$	0.01	0.9	0.7	0.99

边缘化故障得到 $p(H=1) = 0.17$, 从而

$$\begin{aligned} p(A=1 | H=0) &= 0.95 \times 0.01 + 0.05 \times 0.7 = 0.0445, \\ p(A=1 | H=1) &= 0.95 \times 0.9 + 0.05 \times 0.99 = 0.9045, \\ p(A=1) &= 0.83 \times 0.0445 + 0.17 \times 0.9045 = 0.1907, \\ p(F=1, A=1) &= 0.1(0.2 \times 0.0445 + 0.8 \times 0.9045) = 0.07325. \end{aligned}$$

因此精确答案为 $p(F=1 | A=1) = 0.07325/0.1907 \approx 0.384111$ 。若能够取得 10000 个独立后验样本, 故障比例的理论标准误约为 $\sqrt{0.384111(1-0.384111)/10000} = 0.004864$ 。这个小模型的精确答案用于校验采样计算, 不是实际设备数据。

式 (23.3) 不因算法名称中含有“蒙特卡洛”就自动成立。来自提议分布

的样本需要加权，其误差取决于加权函数的方差；同一条 Markov 链上的样本通常相关，必须计入协方差；经重采样产生的粒子可能共享祖先，一般不能视为独立的精确后验样本。独立样本理论是起点，后面每种方法都要重新检查它改变了哪些条件。普通蒙特卡洛的误差分析与方差缩减可参见 Owen 的教材¹。

23.2 独立蒙特卡洛方法

独立蒙特卡洛方法的共同点，是每次使用新的独立随机输入生成一个候选样本，不依赖上一个候选位置。直接采样把候选分布选成目标，拒绝采样通过筛选改变候选分布，重要性采样则保留候选并调整它对估计的贡献。这里的“独立”描述抽样机制；自归一化以后，各个归一化权重会通过共同分母相互关联。

23.2.1 直接采样、祖先采样与拒绝采样

当目标具有可操作的分布形式时，**直接采样**（direct sampling）直接生成具有该分布的随机变量。例如，对离散概率向量构造累积分布，用一个均匀随机数定位所在区间；对 $\mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ ，若 $\boldsymbol{\Sigma} = \boldsymbol{L}\boldsymbol{L}^T$ ，则把独立标准正态向量 $\boldsymbol{\epsilon}$ 变换成 $\boldsymbol{\mu} + \boldsymbol{L}\boldsymbol{\epsilon}$ 即可。一次正确变换给出正确边缘分布，各次使用独立随机输入才给出独立样本。

在有向无环图上，**祖先采样**（ancestral sampling）按拓扑顺序逐个生成节点，使每个节点采样时都已知道其父节点的取值。若一次生成 $\mathbf{x}$ 时，第 i 个节点使用 $p(x_i | \mathbf{x}_{\text{pa}(i)})$ ，则整次生成的概率恰为这些条件概率之积，也就是图模型的联合分布。样本内部的各节点通常不独立，独立的是从头运行得到的不同完整样本。其代价是拓扑遍历加上所有局部采样代价，不能对任意条件分布都默认常数成本。

祖先采样生成联合样本，不直接解决给定证据的后验采样。对设备模型，若按先验生成 F, S, H ，随后不抽取 A 而把它强行设为 1，则保留下来的 F 仍有故障概率 0.1，不是 0.384111。若完整生成 A 并仅保留 $A = 1$ 的样本，保留样本才服从条件分布。这是**拒绝采样**（rejection sampling）的一个特例：候选先由易采样分布产生，再按位置相关的接受概率筛选。

一般地，设 $q(\mathbf{z})$ 为提议密度，已知常数 $c < \infty$ 使 $\gamma(\mathbf{z}) \leq cq(\mathbf{z})$ 在整个目标支撑集上成立。独立生成 $\mathbf{z} \sim q$ 和 $u \sim \text{Uniform}(0, 1)$ ，当 $u \leq \gamma(\mathbf{z})/[cq(\mathbf{z})]$ 时接受。对任意可测集合 B ，

$$\begin{aligned}\mathbb{P}(\mathbf{z} \in B, \text{接受}) &= \int_B q(\mathbf{z}) \frac{\gamma(\mathbf{z})}{cq(\mathbf{z})} d\mathbf{z} = \frac{1}{c} \int_B \gamma(\mathbf{z}) d\mathbf{z}, \\ \mathbb{P}(\text{接受}) &= \frac{Z_x}{c}.\end{aligned}\tag{23.4}$$

¹ A. B. Owen, *Monte Carlo Theory, Methods and Examples*, Online book, 2013, URL: <https://statweb.stanford.edu/~owen/mc/>

相除便得到 $\mathbb{P}(\mathbf{z} \in B \mid \text{接受}) = \int_B p(\mathbf{z} \mid \mathbf{x}) d\mathbf{z}$ 。因此按固定规则独立重复试验，直到得到指定数量的接受样本，会产生独立同分布的目标样本。每个接受样本平均需要 $c/Z_{\mathbf{x}}$ 次提议。包络条件必须全局成立，不能只在已抽到的点上检查，否则接受规则不再有上述保证。

在报警例子中，匹配证据的接受率为 0.1907，平均约 5.244 次联合采样得到一个后验样本。若有多个稀有离散证据，联合匹配概率可能很小；连续证据的精确等值事件通常概率为零，不能靠“恰好抽到观测值”条件化。高维包络也容易变松：若归一化目标和提议分别按坐标分解，每维包络常数为 $m > 1$ ，乘积包络的接受率便是 m^{-d} 。后验越集中而提议越分散，越多计算会用在最终丢弃的候选上。

23.2.2 重要性采样

拒绝采样把一个候选的贡献变成“保留或丢弃”。若给每个候选一个连续权重，就不必寻找全局包络常数。**重要性采样** (importance sampling, IS) 从便于抽样的 q 生成样本，并用目标与提议的密度之比补偿抽样频率的差异。必须满足支撑集覆盖条件：目标赋予正概率的区域不能被 q 完全排除，即 $p \ll q$ 。连续情形的这个条件按测度理解，零测集上的密度取值不影响结论。

如果目标密度已归一化，令 $r(\mathbf{z}) = p(\mathbf{z} \mid \mathbf{x})/q(\mathbf{z})$ ，便有

$$\begin{aligned} I_h &= \int h(\mathbf{z}) r(\mathbf{z}) q(\mathbf{z}) d\mathbf{z}, \\ \hat{I}_{h,n}^{\text{IS}} &= \frac{1}{n} \sum_{i=1}^n r(\mathbf{z}_i) h(\mathbf{z}_i). \end{aligned} \quad (23.5)$$

只要 $\mathbb{E}_p|h| < \infty$ ，这个估计无偏且一致；有限方差还要求 $\mathbb{E}_q[r^2 h^2] < \infty$ 。目标区域若只被 q 赋予很小概率，偶尔出现的巨大权重会主导结果。覆盖支撑集解决的是“能不能到达”，矩条件解决的是“到达次数少到什么程度”，两者不能互相代替。

图模型往往只提供 γ 。令 $w_i = \gamma(\mathbf{z}_i)/q(\mathbf{z}_i)$ ，同时估计分子积分和归一化常数，得到**自归一化重要性采样** (self-normalized importance sampling, SNIS)：

$$\begin{aligned} \hat{Z}_{\mathbf{x}} &= \frac{1}{n} \sum_{i=1}^n w_i, & \bar{w}_i &= \frac{w_i}{\sum_{j=1}^n w_j}, \\ \hat{I}_{h,n}^{\text{SNIS}} &= \frac{\frac{1}{n} \sum_i w_i h(\mathbf{z}_i)}{\frac{1}{n} \sum_i w_i} = \sum_i \bar{w}_i h(\mathbf{z}_i). \end{aligned} \quad (23.6)$$

要求本次权重和非零。 $\hat{Z}_{\mathbf{x}}$ 无偏，但两个无偏估计的比值通常有偏，因为随机分母不能移到期望之外。在支撑集覆盖、 $0 < \mathbb{E}_q w = Z_{\mathbf{x}} < \infty$ 和

$\mathbb{E}_q|wh| < \infty$ 时, 分子、分母分别由大数定律收敛, 故比值仍然一致。有限样本的偏差与渐近正确并不矛盾。

设备例子可以令 $q(f, h, s) = p(f)p(s)p(h | f)$, 不抽取已知的 A , 而令 $w(f, h, s) = p(A = 1 | h, s)$ 。这称为**似然加权** (likelihood weighting): 证据通过似然而非硬性筛选影响候选。图 23.1 比较先验与报警后的 (H, S) 分布。先验最常生成“既不过热也未失灵”, 但这一状态很难解释报警; 乘上似然以后, 它只占约 4.13% 的后验质量。




图 23.1 人工设备模型中 (H, S) 的先验与给定 $A = 1$ 后的后验。横轴每组的两位数依次为 h, s ; 空心蓝柱表示先验, 实心青柱表示后验。权重修正改变的是每类候选的贡献, 不会把未抽到的类别自动补进样本。

表 23.1 给出四个可能的独立先验抽样结果, 仅用来展示计算, 不把这四次抽样当作高精度实验。直接计数得到故障比例 $1/4$; 按似然加权, 得到 $0.9/(0.01 + 0.9 + 0.9 + 0.7) \approx 0.358566$ 。这个值仍与精确后验不同, 但各候选的贡献已按目标分布修正。

样本 i	(f_i, h_i, s_i)	w_i	$\mathbb{I}\{f_i = 1\}$	$w_i \mathbb{I}\{f_i = 1\}$
1	(0, 0, 0)	0.01	0	0
2	(1, 1, 0)	0.90	1	0.90
3	(0, 1, 0)	0.90	0	0
4	(0, 0, 1)	0.70	0	0

表 23.1 似然加权的四样本教学计算。分母是全部权重之和, 分子仅累加故障样本的权重。

提议分布并非只需靠近后验峰值。为估计尾部事件, 它还必须充分覆盖相关尾部。以一维标准正态目标 $p = \mathcal{N}(0, 1)$ 和 $q = \mathcal{N}(0, s^2)$ 为例, 二者的支撑集相同, 但

$$\frac{p(z)^2}{q(z)} \propto \exp\left[\left(-1 + \frac{1}{2s^2}\right)z^2\right].$$

因此 $\mathbb{E}_q r^2$ 只有在 $s^2 > 1/2$ 时才有限。提议过窄时, 算法可以满足一致性的条件, 却没有通常所需的有限权重二阶矩; 重复运行中偶发的大权重会

破坏熟悉的误差估计。如何构造尾部足够宽、同时不过度浪费样本的提议，是重要性采样的主要计算问题；相关分析可参见 Owen 教材的第 9 章²。

² A. B. Owen, *Monte Carlo Theory, Methods and Examples*, Online book, 2013, URL: <https://statweb.stanford.edu/~owen/mc/>

23.2.3 方差缩减

增加样本并非降低 MCSE 的唯一办法。有些随机波动可以用已知的解析关系消除。**控制变量** (control variate) 就是一个均值已知、且与待估函数共同变化的辅助量。设独立样本来自 p , $\mathbb{E}_p g = \mu_g$ 已知, 并且 h, g 均有有限二阶矩。对固定系数 β ,

$$\hat{I}_{h,n}^{\text{CV}} = \frac{1}{n} \sum_{i=1}^n [h(\mathbf{z}_i) - \beta(g(\mathbf{z}_i) - \mu_g)]. \quad (23.7)$$

被减去的项期望为零, 所以估计仍无偏。其单样本方差为

$$\text{Var}(h) - 2\beta \text{Cov}(h, g) + \beta^2 \text{Var}(g).$$

若 $\text{Var}(g) > 0$, 对 β 求导得最优系数 $\beta^* = \text{Cov}(h, g) / \text{Var}(g)$, 最小方差为 $\text{Var}(h)(1 - \rho_{h,g}^2)$, 其中 $\rho_{h,g}$ 为相关系数。相关越强, 能够扣除的共同波动越多。若用同一批样本拟合 β , 系数就不再固定, 有限样本无偏性不能直接沿用; 可用独立试运行确定系数, 再固定系数估计。

一个可手算的例子是 $Z \sim \text{Uniform}(0, 1)$, $h(Z) = Z^2$, $g(Z) = Z$ 。因为 $\mathbb{E} Z^k = 1/(k+1)$, 有 $\text{Var}(Z^2) = 4/45$, $\text{Var}(Z) = 1/12$ 和 $\text{Cov}(Z^2, Z) = 1/12$, 故 $\beta^* = 1$ 。对 $Z^2 - Z + 1/2$ 求均值, 其单样本方差为 $4/45 - 1/12 = 1/180$, 是原方差的 $1/16$ 。这里额外成本只是计算一个已知均值的辅助函数。

图模型的局部解析计算还可直接替代一部分抽样。**Rao-Blackwell 化** (Rao-Blackwellization) 把一个随机估计替换为给定部分变量后的条件期望, 也就是保留必要的随机性, 把其余随机性积分掉。对平方可积的 $h(U, V)$, 令 $\tilde{h}(U) = \mathbb{E}[h(U, V) | U]$, 全期望和全方差公式给出

$$\begin{aligned} \mathbb{E}[\tilde{h}(U)] &= \mathbb{E}[h(U, V)], \\ \text{Var}(h(U, V)) &= \text{Var}(\tilde{h}(U)) + \mathbb{E}[\text{Var}(h(U, V) | U)]. \end{aligned} \quad (23.8)$$

第二项非负, 证明了单样本方差不增。条件期望不是取一个“平均状态”再代入 h ; 非线性函数一般满足 $\mathbb{E}[h(V) | U] \neq h(\mathbb{E}[V | U])$ 。

若目标是设备的先验报警概率, 可以抽取完整 (F, H, S, A) 并平均 $\mathbb{I}\{A = 1\}$, 也可以只抽取 F , 把其余节点解析消去。后者每次贡献 $p(A = 1 | F)$: 当 $F = 0$ 时为 0.1305, 当 $F = 1$ 时为 0.7325。两者均值都是 0.1907, 但前者单样本方差为 $0.1907(1 - 0.1907) = 0.15433351$, 后者为 $0.1 \times 0.9(0.7325 - 0.1305)^2 = 0.03261636$ 。解析计算减少了相同独立抽样次数下的方差; 是否节约总时间, 还要比较条件积分的成本。

对自归一化重要性采样，需按提议的条件分布同时积分分子贡献 wh 和分母贡献 w ，不能只把 h 替换为某个后验条件均值而保留不相容的权重。对 MCMC，单次函数值的方差变小也不自动意味着整个均值的渐近方差变小，因为自相关可能改变。Rao-Blackwell 化提供的基本不等式是式 (23.8)，扩展到具体采样机制时仍要分析完整估计量。

23.3 Markov 链蒙特卡洛

在高维后验中，构造覆盖充分的独立提议可能与直接求后验同样困难。如果只要求从当前位置产生下一位置，便可以利用局部条件分布、局部密度比或梯度。**Markov 链蒙特卡洛** (Markov chain Monte Carlo, MCMC) 通过这样的局部转移形成相关样本序列，再用长期平均近似目标期望。它不要求每一步已经是后验抽样，而要求转移持续运行后能够正确访问目标分布。

23.3.1 Markov 转移与目标分布

令 $\mathbf{z}^{(k)}$ 表示第 k 次迭代的状态，迭代上标与真实时间下标区分。一个**转移核** (transition kernel) $K(\mathbf{z}, B)$ 给出从当前位置 $\mathbf{z}$ 一步进入集合 B 的概率；Markov 性质表示下一步只依赖当前状态，而不再依赖更早的状态。目标分布的不变性要求

$$\int p(\mathbf{z} | \mathbf{x}) K(\mathbf{z}, B) d\mathbf{z} = \int_B p(\mathbf{z}' | \mathbf{x}) d\mathbf{z}'. \quad (23.9)$$

满足此式时， p 称为**平稳分布** (stationary distribution)：若当前状态已服从 p ，再转移一步仍服从 p 。保持不变的是状态的概率分布，单条样本轨迹仍可不断移动；这也不保证从任意初始状态出发，后续状态的分布都能收敛到 p 。

一个便于验证的充分条件是**细致平衡** (detailed balance)。先考虑有限状态，令 π_i 为目标分布处于状态 i 的概率， $K_{i,j}$ 为从 i 一步转移到 j 的条件概率。细致平衡要求

$$\pi_i K_{i,j} = \pi_j K_{j,i} \quad \text{对所有 } i, j \text{ 成立.}$$

左边是“当前在 i 且下一步到 j ”的联合概率，右边是反向转移的联合概率。例如取两个状态的目标分布与转移矩阵

$$\boldsymbol{\pi} = (0.8, 0.2), \quad \mathbf{K} = \begin{pmatrix} 0.9 & 0.1 \\ 0.4 & 0.6 \end{pmatrix},$$

矩阵每行对应当前状态，每列对应下一状态。两个状态之间的正向流量是 $0.8 \times 0.1 = 0.08$ ，反向流量是 $0.2 \times 0.4 = 0.08$ ，正好相等。对固定 j 将细致

平衡等式按 i 求和, 得到 $\sum_i \pi_i K_{i,j} = \pi_j \sum_i K_{j,i} = \pi_j$, 所以一步后的分布仍是 π 。

对一般状态空间, 同一条件写成

$$p(dz | x)K(z, dz') = p(dz' | x)K(z', dz). \quad (23.10)$$

左右两侧是平稳运行时相反方向的联合概率流。使用测度记号, 是因为拒绝后停留原地会产生点质量, 转移未必有普通密度。对 z 积分, 右侧的 $K(z', \cdot)$ 总质量为 1, 于是得到式 (23.9)。满足细致平衡的链称为可逆链, 但可逆性不是不变性的必要条件; 顺次组合多个保持 p 的核仍保持 p , 组合后的核却未必可逆。

两个反例说明还缺什么。恒等核 $K(z, B) = \mathbb{I}\{z \in B\}$ 保持任何分布, 也满足细致平衡, 却永远不离开初始点。**不可约性** (irreducibility) 排除这种互不连通的封闭区域: 从允许的初始状态出发, 任何具有正目标概率的集合都应能在某个有限步数内以正概率到达。另一条链在状态 0, 1 间确定性交替, 平稳分布为 $(1/2, 1/2)$, 且不可约, 但每一步的分布始终交替。**非周期性** (aperiodicity) 排除这样的固定循环节律。

有限状态空间中, 不可约性给出唯一平稳分布; 再加非周期性, 状态分布从任何起点收敛到它。即便周期链的逐步分布不收敛, 时间平均仍可能收敛, 例如上面的交替链。一般连续状态空间更需控制返回行为, 常用的**正 Harris 常返性** (positive Harris recurrence) 要求链从每个允许起点出发, 对每个正概率区域都以概率 1 反复访问, 并存在不变概率分布; 结合非周期性, 可得到逐步分布的收敛, 且可积函数的时间平均满足遍历大数定律。这里给出这些定理的使用条件, 不把有限状态证明直接搬到连续空间; 一般状态空间的精确陈述与证明见 Roberts 和 Rosenthal³。

算法设计通常先证明不变性, 再检查可达性和返回条件。**混合** (mixing) 描述链摆脱初值并探索目标分布的速度; 即使渐近定理成立, 跨越两个高概率区域之间的低概率区域也可能非常缓慢。对某个核证明“目标正确”, 与证明“给定预算内能准确估计”是两件不同的事。

³ G. O. Roberts, J. S. Rosenthal, *General State Space Markov Chains and MCMC Algorithms* In Probability Surveys, 2004, vol. 1, pp. 20–71

23.3.2 Metropolis–Hastings 方法

给定当前位置 z , 设易采样提议为 $q(z' | z)$ 。若直接接受, 往返概率流一般不相等。**Metropolis–Hastings 方法** (Metropolis–Hastings, MH) 通过位置相关的接受率, 让实际往返流量都等于提议流量中较小的一方:

$$\alpha(z, z') = \min \left\{ 1, \frac{\gamma(z')q(z | z')}{\gamma(z)q(z' | z)} \right\}. \quad (23.11)$$

从 $\gamma(\mathbf{z}) > 0$ 的有效状态开始，提议到目标质量为零或无法反向提议的状态时拒绝；未实际提议到的零分母情形不参与该比值的计算。对两个不同状态，接受后的概率流为

$$\begin{aligned} p(\mathbf{z} | \mathbf{x})q(\mathbf{z}' | \mathbf{z})\alpha(\mathbf{z}, \mathbf{z}') \\ = \frac{\min\{\gamma(\mathbf{z})q(\mathbf{z}' | \mathbf{z}), \gamma(\mathbf{z}')q(\mathbf{z} | \mathbf{z}')\}}{Z_x}. \end{aligned}$$

右侧交换 $\mathbf{z}, \mathbf{z}'$ 后不变；拒绝产生的原地停留也满足细致平衡。因此 MH 保持目标分布，并且不需要知道 Z_x 。

一次迭代先抽提议，再抽一个独立均匀数决定接受与否。接受时记录 $\mathbf{z}'$ ，拒绝时仍记录 $\mathbf{z}$ ，随后开始下一次迭代。不能只收集接受的点：有些状态本就需要停留更久，删除重复状态会改变各区域的访问比例。MH 的“拒绝”与独立拒绝采样的“丢弃候选”在这里有根本区别。

随机游走提议常写作 $\mathbf{z}' = \mathbf{z} + \epsilon\boldsymbol{\eta}$ ，其中 $\boldsymbol{\eta} \sim \mathcal{N}(\mathbf{0}, \mathbf{C})$ ， ϵ 为尺度， $\mathbf{C}$ 为给定正定矩阵。提议对称时，接受率只剩目标密度比。对标准正态目标，从 $z = 0$ 提议到 $z' = 2$ 的接受率是 $\exp(-2) \approx 0.1353$ ，反向提议则总被接受。尺度过小时，接受率虽高，每步位移却很小；尺度过大时，候选常落入低密度区域，链又因拒绝而停留。

维度会加重这一矛盾。对 $p(\mathbf{z}) \propto \exp(-\|\mathbf{z}\|_2^2/2)$ 和各向同性提议，势能变化为

$$\frac{\|\mathbf{z} + \epsilon\boldsymbol{\eta}\|_2^2 - \|\mathbf{z}\|_2^2}{2} = \epsilon\mathbf{z}^\top\boldsymbol{\eta} + \frac{\epsilon^2}{2}\|\boldsymbol{\eta}\|_2^2.$$

典型情况下 $\|\boldsymbol{\eta}\|_2^2$ 随维度 d 增长，固定尺度会让接受困难；缩小尺度又减缓每个坐标的探索。这个计算解释了维度敏感性，但并不是对任意后验都成立的最优尺度定理。

独立提议 (independence proposal) 取 $q(\mathbf{z}' | \mathbf{z}) = q(\mathbf{z}')$ 。候选不依赖当前位置，但接受后的链仍然相关。它能一次跨越很远的区域，接受率却变成 $\min\{1, w(\mathbf{z}')/w(\mathbf{z})\}$ ，其中 $w = \gamma/q$ ；一旦链进入 q 严重低估的区域，就容易长时间停留。独立提议依赖全局分布近似，随机游走依赖局部尺度适配，两者不能仅以接受率高低排序。

23.3.3 Gibbs 采样

图模型常允许直接计算一个变量在其余变量给定时的条件分布。**Gibbs 采样** (Gibbs sampling) 固定其余坐标，仅从待更新坐标的**满条件分布** (full conditional distribution) 重新抽样；“满”表示已经给定其他全部未知变量及证据。记 $\mathbf{z}_{-j}$ 为去掉第 j 个坐标后的向量，则单坐标更新使用 $p(z_j | \mathbf{z}_{-j}, \mathbf{x})$ 。顺序扫描时，一轮中已更新的坐标使用新值，尚未更新的坐标使用旧值。

为什么精确条件抽样不需要拒绝？把固定 $\mathbf{z}_{-j}$ 时的提议写成 $q(z'_j |$

$z_j, \mathbf{z}_{-j}) = p(z'_j | \mathbf{z}_{-j}, \mathbf{x})$, MH 比值为

$$\frac{p(z'_j, \mathbf{z}_{-j} | \mathbf{x}) p(z_j | \mathbf{z}_{-j}, \mathbf{x})}{p(z_j, \mathbf{z}_{-j} | \mathbf{x}) p(z'_j | \mathbf{z}_{-j}, \mathbf{x})} = 1. \quad (23.12)$$

等式来自联合分布的条件分解, 并要求涉及的条件分布定义良好。每个更新核都保持后验, 故依次组合一整轮也保持后验。若用近似满条件作提议, 就不再有这个抵消; 必须加入相应 MH 校正, 或另行证明近似更新的偏差与收敛性质。随机扫描各选一个坐标与确定性顺序扫描都可构造正确核, 但整轮顺序扫描一般不满足细致平衡。

满条件虽然写成“给定所有其他变量”, 实际计算通常只涉及邻近因子。有向图中, 一个节点的**Markov 毯** (Markov blanket) 由父节点、子节点以及子节点的其他父节点组成; 给定这些变量以后, 其余节点不再改变该节点的条件分布。用 $\text{ch}(j)$ 记子节点集合, 含有 z_j 的局部因子给出

$$p(z_j | \mathbf{z}_{-j}, \mathbf{x}) \propto p(z_j | \text{父节点}) \prod_{\ell \in \text{ch}(j)} p(v_\ell | \text{其父节点}),$$

其中 v_ℓ 表示子节点的当前取值, 证据节点使用已观测值。无向图只需相乘所有包含该节点的势函数, 再对候选 z_j 归一化。这一局部性减少单步计算, 不意味着一轮更新后所有变量已成为独立后验样本。

在设备后验 $p(f, h, s | A = 1)$ 上, 更新 F 时只需 H ; 若 $H = 1$,

$$p(F = 1 | H = 1, A = 1, S) = \frac{0.1 \times 0.8}{0.1 \times 0.8 + 0.9 \times 0.1} = \frac{8}{17}.$$

更新 H 时则需 F, S, A ; 若 $F = 1, S = 0, A = 1$, 取 $H = 1$ 和 $H = 0$ 的未归一化概率分别为 $0.8 \times 0.9 = 0.72$ 和 $0.2 \times 0.01 = 0.002$, 故前者的满条件概率是 $0.72/0.722 \approx 0.997230$ 。更新 S 时, 若 $H = 0, A = 1$, 则

$$p(S = 1 | H = 0, A = 1, F) = \frac{0.05 \times 0.7}{0.05 \times 0.7 + 0.95 \times 0.01} \approx 0.786517.$$

这三步展示了证据如何通过局部更新传播, 而无须每次重新消去整张图。对有 K 个取值的节点, 一次朴素更新需评估 K 组相关因子; 块越大, 联合条件分布的构造和抽样成本通常越高。

接受率恒为一并不等于混合快。以零均值、相关系数 $\rho \in (-1, 1)$ 、边缘方差为 1 的二维高斯为例, 满条件方差均为 $1 - \rho^2$ 。当 ρ 接近 1 时, 给定一个坐标后另一个只能小幅移动。顺序更新满足

$$\begin{aligned} z_1^{(k+1)} &= \rho z_2^{(k)} + \sqrt{1 - \rho^2} \epsilon_1, \\ z_2^{(k+1)} &= \rho z_1^{(k+1)} + \sqrt{1 - \rho^2} \epsilon_2, \end{aligned}$$

其中每轮使用两个新的独立标准正态噪声 ϵ_1, ϵ_2 。代入可见 z_2 跨一轮的自

回归系数为 ρ^2 ；即使每次都接受， $\rho = 0.99$ 时仍有 0.9801 的一步相关。

分块 Gibbs 采样 (blocked Gibbs sampling) 联合更新强相关坐标，使提议能沿相关方向移动。**折叠 Gibbs 采样** (collapsed Gibbs sampling) 先解析消去部分变量，再对剩余变量构造满条件更新；需要完整样本时，可随后按被消去变量的条件分布补抽。折叠可能降低维度和依赖，也可能形成更稠密的因子、提高单步成本；不能把不同边缘分布下的条件更新任意拼接。若确定性约束导致单坐标更新无法离开某个配置，链甚至不可约性都不满足，需改变分块或参数化，而不是单纯增加迭代次数。Koller 与 Friedman 教材的第 12 章讨论了这些采样构造及其限制⁴。

⁴ D. Koller, N. Friedman, *Probabilistic Graphical Models: Principles and Techniques*, MIT Press, 2009

23.3.4 Hamiltonian Monte Carlo

对连续、可微且强相关的后验，随机游走常把计算耗在短距离探索上。**哈密顿蒙特卡洛** (Hamiltonian Monte Carlo, HMC) 引入辅助动量，让当前位置沿由梯度决定的轨迹移动，再把轨迹末端作为一次整体提议。它利用的是保持扩展分布的动力学，不是把梯度下降的终点当作后验样本。

以下讨论 $\mathbb{R}^d$ 上 $\gamma > 0$ 且足够光滑的情形，使用固定正定**质量矩阵** (mass matrix) $\mathbf{M}$ 控制不同方向的运动尺度。令辅助动量 $\mathbf{r} \in \mathbb{R}^d$ 服从 $\mathcal{N}(\mathbf{0}, \mathbf{M})$ ，定义势能 $U(\mathbf{z}) = -\log \gamma(\mathbf{z})$ 和总能量

$$\begin{aligned} H(\mathbf{z}, \mathbf{r}) &= U(\mathbf{z}) + \frac{1}{2} \mathbf{r}^\top \mathbf{M}^{-1} \mathbf{r}, \\ \tilde{p}(\mathbf{z}, \mathbf{r}) &= p(\mathbf{z} | \mathbf{x}) \mathcal{N}(\mathbf{r}; \mathbf{0}, \mathbf{M}) \propto \exp[-H(\mathbf{z}, \mathbf{r})]. \end{aligned} \quad (23.13)$$

把动量积分掉，仍得到原目标后验。动量只是计算辅助变量；其分布与 $\mathbf{z}$ 独立，因而每轮在保持 $\mathbf{z}$ 不变时重新抽取 $\mathbf{r}$ ，就是扩展分布上的一次精确条件更新。这一**动量刷新** (momentum refreshment) 保持 $\tilde{p}$ ，并使相邻轨迹能具有不同能量和方向。若只做确定性能量守恒运动而不刷新，轨迹会局限在某个能量面，通常无法遍历扩展分布。

用 s 表示轨迹内部的人工连续时间，避免与观测时间混淆。Hamilton 方程为

$$\frac{d\mathbf{z}}{ds} = \mathbf{M}^{-1} \mathbf{r}, \quad \frac{d\mathbf{r}}{ds} = -\nabla U(\mathbf{z}). \quad (23.14)$$

沿精确轨迹，总能量的导数为

$$\frac{dH}{ds} = \nabla U(\mathbf{z})^\top \mathbf{M}^{-1} \mathbf{r} - (\mathbf{M}^{-1} \mathbf{r})^\top \nabla U(\mathbf{z}) = 0.$$

动能与势能可以互换，所以位置能离开局部高密度点而不必使总能量上升。精确流还保体积：相空间向量场 $(\mathbf{M}^{-1} \mathbf{r}, -\nabla U(\mathbf{z}))$ 的散度为零，因为前一分量不依赖 $\mathbf{z}$ ，后一分量不依赖 $\mathbf{r}$ 。在流存在且光滑的区间内，Jacobian 行列式因而为 1。能量守恒保持密度值，体积保持保证没有额外挤压或稀释概率质量；两者合起来才保持 $\tilde{p}$ 。

计算机不能一般性地求出精确轨迹。常用的**蛙跳积分** (leapfrog integration) 将一步分成动量半步、位置整步、动量半步。以 $(\mathbf{z}, \mathbf{r})$ 为输入、步长为 ϵ ,

$$\begin{aligned} \mathbf{r}_{1/2} &= \mathbf{r} - \frac{\epsilon}{2} \nabla U(\mathbf{z}), \\ \mathbf{z}' &= \mathbf{z} + \epsilon \mathbf{M}^{-1} \mathbf{r}_{1/2}, \\ \mathbf{r}' &= \mathbf{r}_{1/2} - \frac{\epsilon}{2} \nabla U(\mathbf{z}'). \end{aligned} \quad (23.15)$$

下标 1/2 只是一步内部的半步标记。这个积分器通常不精确守恒 H , 却在精确算术下保留两个用于校正的关键性质。

保体积可以逐步验证。动量更新的 Jacobian 是对角块均为单位矩阵的下三角块矩阵, 位置更新则是相应的上三角块矩阵; 二者行列式均为 1。三步复合以及重复 L 步后的映射 Φ_ϵ^L 仍保体积。可逆性来自对称的半步排列: 把末端动量变号, 按相同步长和步数再运行, 再次变号, 就回到起点。令 $R(\mathbf{z}, \mathbf{r}) = (\mathbf{z}, -\mathbf{r})$, 则

$$R\Phi_\epsilon^L R = (\Phi_\epsilon^L)^{-1}, \quad T = R\Phi_\epsilon^L, \quad T^2 = \text{id}. \quad (23.16)$$

因此“积分后翻转动量”的提议 T 是一个自身为逆的保体积映射。翻转不改变动能, 其作用是让提议明确具有可对应的反向路径。

设 $\mathbf{y} = (\mathbf{z}, \mathbf{r})$ 、 $\mathbf{y}' = T\mathbf{y}$, 末端**Metropolis 校正** (Metropolis correction) 的接受率为

$$\alpha_H(\mathbf{y}, \mathbf{y}') = \min\{1, \exp[-H(\mathbf{y}') + H(\mathbf{y})]\}. \quad (23.17)$$

这不是任意确定性变换都可使用的公式: 自身为逆使正反提议配对, 保体积使 Jacobian 修正为 1。两方向的接受流量都正比于

$$\min\{\exp[-H(\mathbf{y})], \exp[-H(\mathbf{y}')]\},$$

因而满足扩展空间的细致平衡。刷新动量与该接受/拒绝更新各自保持 $\tilde{p}$, 两者复合也保持它; 只保留位置就得到保持原后验的转移核。由此可见, 可逆积分、体积保持与末端校正分别解决不同问题, 不能只保留“利用梯度前进”这一步⁵。

算法 23.1 固定步长与轨迹长度的 HMC

输入: 初始位置 $\mathbf{z}^{(0)}$, $U, \nabla U$, 固定 $\mathbf{M}, \epsilon, L$, 迭代数 n

输出: 含拒绝后重复位置的 n 个 MCMC 样本

- 1: **for** $k = 0, \dots, n-1$ **do**
- 2: 抽取 $\mathbf{r} \sim \mathcal{N}(\mathbf{0}, \mathbf{M})$, 记 $\mathbf{y} = (\mathbf{z}^{(k)}, \mathbf{r})$
- 3: 从 $\mathbf{y}$ 按式 (23.15) 积分 L 步
- 4: 翻转末端动量, 得到 $\mathbf{y}' = (\mathbf{z}', -\mathbf{r}')$
- 5: 抽取 $u \sim \text{Uniform}(0, 1)$

⁵ R. M. Neal, “MCMC Using Hamiltonian Dynamics”, in: *Handbook of Markov Chain Monte Carlo*, ed. by S. Brooks, A. Gelman, G. L. Jones, X.-L. Meng, Chapman and Hall/CRC, 2011, chap. 5, pp. 113–162

```

6:   if  $u \leq \alpha_H(\mathbf{y}, \mathbf{y}')$  then
7:      $\mathbf{z}^{(k+1)} \leftarrow \mathbf{z}'$ 
8:   else
9:      $\mathbf{z}^{(k+1)} \leftarrow \mathbf{z}^{(k)}$ 
10:  end if
11:  记录  $\mathbf{z}^{(k+1)}$ ; 本轮动量随后丢弃
12: end for

```

对 $p(z) = \mathcal{N}(0, 1)$ 、 $M = 1$ ，有 $U(z) = z^2/2$ 。从 $(z, r) = (0, 1)$ 以 $\epsilon = 0.5$ 走一步，得到 $r_{1/2} = 1$ 、 $z' = 0.5$ 和 $r' = 0.875$ 。起点能量为 0.5，末端为 $(0.5^2 + 0.875^2)/2 = 0.5078125$ ，所以接受率为 $\exp(-0.0078125) \approx 0.992218$ 。图 23.2 把这个离散步与精确能量圆并列，说明“小积分误差”不等于“无需校正”。若每次都接受离散积分结果，一般会改变目标分布；Metropolis 步骤纠正的是这一离散化误差，不是消除有限链长和慢混合问题。




图 23.2 标准正态目标的一步 HMC 计算。左图中虚线圆弧属于 $H = 1/2$ 的精确轨迹，折线表示 $\epsilon = 0.5$ 的蛙跳位置整步与末端动量半步；初始动量半步因 $z = 0$ 而不动。右图区分保持扩展分布的动量刷新与校正更新；末端动量翻转未画在相图上。

步长 ϵ 决定局部积分精度，轨迹长度 $\tau = L\epsilon$ 决定一次提议运动多久。在足够光滑、数值稳定且 τ 固定的条件下，蛙跳的全局状态误差为 $O(\epsilon^2)$ ；在相应有限区域内，能量误差也可控制在这一阶。但误差常数依赖曲率、维度与轨迹，不能只凭“小步长”断言采样良好。过大步长可能造成能量误差突然增大、非有限数值或拒绝；此类积分失败应拒绝并记录。过短轨迹探索不足，过长轨迹可能绕回原处，增加梯度计算却没有相应收益。

质量矩阵改变的是运动几何。在高斯目标 $\mathcal{N}(\mathbf{0}, \Sigma)$ 下，

$$\frac{d^2 \mathbf{z}}{ds^2} = -\mathbf{M}^{-1} \Sigma^{-1} \mathbf{z}.$$

按本章动量协方差等于 $\mathbf{M}$ 的约定，取 $\mathbf{M} = \Sigma^{-1}$ 会把所有方向的频率变为 1。有的软件把相反矩阵称作“度量”或“逆质量”，实现时必须核对约定，

不能仅凭名称照搬协方差。固定矩阵只能补偿全局线性尺度，不能消除随位置变化的狭窄区域或多峰障碍。通常在预热阶段调整尺度，正式保留样本时固定参数；任意依赖历史的持续调整不能直接套用上述齐次链证明。

若一次梯度求值成本为 $C_{\nabla U}$ ，一轮 HMC 约需 $O(LC_{\nabla U})$ ，另加动量生成和质量矩阵运算。对角矩阵的线性代数成本为 $O(d)$ 每步，稠密矩阵通常为 $O(d^2)$ 每步，并需预先分解。标准 HMC 不能直接更新离散变量；受约束连续变量常需先变换到无约束空间，并把变换的 Jacobian 加入密度。即使积分精确，某些固定轨迹长度也会产生共振而妨碍遍历，因此不变性并未替代对链探索能力的检查。

23.4 序贯蒙特卡洛

现在把一次报警改成持续到来的传感器观测。每收到一条观测都从头运行一个静态采样器，会丢掉已经完成的计算。**序贯蒙特卡洛** (sequential Monte Carlo, SMC) 用一组带权样本逐步追踪一列目标分布；这些样本称为**粒子** (particle)，每个粒子代表一种可能的潜在状态或状态历史，而不是实际物体。

为建立最小动态设定，令潜在状态为 $\mathbf{z}_t$ 、观测为 $\mathbf{x}_t$ ，真实时间 $t = 1, \dots, T$ 写作下标。初始分布为 $p(\mathbf{z}_1)$ ，转移分布为 $p(\mathbf{z}_t | \mathbf{z}_{t-1})$ ，观测分布为 $p(\mathbf{x}_t | \mathbf{z}_t)$ 。其联合分布分解为

$$\begin{aligned} p(\mathbf{z}_{1:T}, \mathbf{x}_{1:T}) \\ = p(\mathbf{z}_1)p(\mathbf{x}_1 | \mathbf{z}_1) \prod_{t=2}^T p(\mathbf{z}_t | \mathbf{z}_{t-1})p(\mathbf{x}_t | \mathbf{z}_t). \end{aligned} \quad (23.18)$$

这里假设给定上一潜状态后，更早状态不再影响当前状态；给定当前潜状态后，当前观测不再依赖其余变量。**滤波** (filtering) 的目标是 $p(\mathbf{z}_t | \mathbf{x}_{1:t})$ ，只利用截至当前的观测估计当前状态。若利用未来观测估计过去状态，则是平滑问题。本节只建立粒子计算所需的模型；第 28.1 节将从动态有向分解系统建立这些查询，第 28.3 节再比较何时可以用解析滤波代替粒子近似。

SMC 不只适用于物理时间。一列 $\gamma_\ell(\mathbf{z}) = p(\mathbf{z})p(\mathbf{x} | \mathbf{z})^{\beta_\ell}$ ，其中 $0 = \beta_0 < \dots < \beta_L = 1$ ，也可让粒子逐步从先验迁移到后验，并在相邻目标间更新权重、重采样和进行 MCMC 移动。这时 ℓ 是算法阶段，不是观测时间。本节以**粒子滤波** (particle filtering) 为主，即用 SMC 近似式 (23.18) 的滤波分布。

23.4.1 序贯重要性采样

若直接对整条路径 $\mathbf{z}_{1:t}$ 做重要性采样, 路径长度随 t 增长, 看似每次都要重新生成历史。Markov 分解允许复用旧路径, 只向后延伸一步。**序贯重要性采样** (sequential importance sampling, SIS) 把路径提议写成

$$q_{1:t}(\mathbf{z}_{1:t} | \mathbf{x}_{1:t}) = q_1(\mathbf{z}_1 | \mathbf{x}_1) \prod_{s=2}^t q_s(\mathbf{z}_s | \mathbf{z}_{1:s-1}, \mathbf{x}_{1:s}),$$

其中早先已经使用的 q_s 不因后来观测而被追溯修改。选择未归一化路径目标 $\gamma_t = p(\mathbf{z}_{1:t}, \mathbf{x}_{1:t})$, 将目标分解除以提议分解, 公共前缀相消, 得到

$$\begin{aligned} w_{1,i} &= \frac{p(\mathbf{z}_{1,i})p(\mathbf{x}_1 | \mathbf{z}_{1,i})}{q_1(\mathbf{z}_{1,i} | \mathbf{x}_1)}, \\ w_{t,i} &= w_{t-1,i} \frac{p(\mathbf{z}_{t,i} | \mathbf{z}_{t-1,i})p(\mathbf{x}_t | \mathbf{z}_{t,i})}{q_t(\mathbf{z}_{t,i} | \mathbf{z}_{1:t-1,i}, \mathbf{x}_{1:t})}. \end{aligned} \quad (23.19)$$

下标 $i = 1, \dots, n$ 标记粒子, $\mathbf{z}_{1:t,i}$ 是第 i 条路径。提议必须覆盖其对应的目标条件支撑集。权重的绝对尺度对归一化均值无影响, 因此递推时可用上一时刻的归一化权重, 再统一归一化当前权重。

只保留路径末端, 就得到滤波分布的经验近似

$$\begin{aligned} \hat{p}_t(d\mathbf{z}) &= \sum_{i=1}^n \bar{w}_{t,i} \delta_{\mathbf{z}_{t,i}}(d\mathbf{z}), \\ \hat{I}_{t,h} &= \sum_{i=1}^n \bar{w}_{t,i} h(\mathbf{z}_{t,i}). \end{aligned} \quad (23.20)$$

其中 $\delta_{\mathbf{z}_{t,i}}$ 是把全部概率质量放在该粒子位置的点质量分布, 不是连续密度曲线。对连续状态, 有限粒子近似与连续目标不可能在总变差距离下趋近; 通常讨论的是适当测试函数 h 的积分是否收敛。

最简单的提议是模型转移 $q_t = p(\mathbf{z}_t | \mathbf{z}_{t-1})$, 此时新权重只是旧权重乘以当前观测似然。它易于实现, 却在新观测极具信息时浪费粒子, 因为传播时尚未利用 $\mathbf{x}_t$ 。对固定上一状态, 更有针对性的提议是

$$\begin{aligned} q_t^*(\mathbf{z}_t | \mathbf{z}_{t-1}, \mathbf{x}_t) &= \frac{p(\mathbf{z}_t | \mathbf{z}_{t-1})p(\mathbf{x}_t | \mathbf{z}_t)}{p(\mathbf{x}_t | \mathbf{z}_{t-1})}, \\ p(\mathbf{x}_t | \mathbf{z}_{t-1}) &= \int p(\mathbf{x}_t | \mathbf{z}_t)p(\mathbf{z}_t | \mathbf{z}_{t-1}) d\mathbf{z}_t. \end{aligned} \quad (23.21)$$

它使式 (23.19) 中的增量变成只依赖父粒子的 $p(\mathbf{x}_t | \mathbf{z}_{t-1,i})$, 因而在给定父粒子的条件下, 增量权重方差为零。这个“最优”只针对一步条件方差: 不同父粒子的预测似然和旧权重仍可能不同, 且 q_t^* 本身可能难以计算或抽样。

不重采样的 SIS 会把许多个增量相乘。若少数路径持续更符合观测, 其

权重会逐步占据总和的大部分，其他粒子虽仍占用计算，却几乎不影响答案。这称为**权重退化**（weight degeneracy）。在对数尺度上累加权重，并减去最大对数权重后再指数化，可以防止数值下溢，却不能消除这种真实的统计退化。

23.4.2 粒子滤波与重采样

一个自然的补救是把下一轮计算资源更多地分给高权重粒子。**重采样**（resampling）按当前权重随机复制或淘汰粒子，把带权经验分布转成等权样本集合。若 N_i 为第 i 个原粒子的后代数，基本要求是

$$\sum_i N_i = n, \quad \mathbb{E}[N_i | \mathcal{F}_t] = n\bar{w}_{t,i}, \quad (23.22)$$

其中 $\mathcal{F}_t$ 表示重采样前已有的全部粒子信息。由此，

$$\mathbb{E} \left[\frac{1}{n} \sum_i N_i h(\mathbf{z}_{t,i}) \middle| \mathcal{F}_t \right] = \sum_i \bar{w}_{t,i} h(\mathbf{z}_{t,i}).$$

重采样保持的是当前经验估计的条件期望，不是保证每次复制后估计都不变，也不是把近似粒子变成真实后验的独立样本。

三种常见方法都可以通过累积权重 $C_j = \sum_{i=1}^j \bar{w}_{t,i}$ 实现。给定 $u \in (0, 1)$ ，取最小的 j 使 $C_j \geq u$ ，便选中原粒子 j 。差异只在如何选择 n 个 u ，见表 23.2。

方法	均匀数的构造	主要性质
多项式	n 个独立的 $u_i \sim \text{Uniform}(0, 1)$	后代数服从多项式分布，条件方差易分析
分层	各区间 $((i-1)/n, i/n)$ 独立抽一个 u_i	每层均被使用，估计的条件方差不高于多项式法
系统	抽一个 $u \sim \text{Uniform}(0, 1/n)$ ，令 $u_i = u + (i-1)/n$	只需一个随机偏移，结果受粒子排列影响

表 23.2 固定粒子数的三种重采样。分层法的方差比较针对相同加权粒子集合和相同测试函数；系统法没有对所有排列及函数都成立同类优越性保证。

多项式重采样（multinomial resampling）在给定 $\mathcal{F}_t$ 后独立选取 n 个祖先，其均值估计的条件方差是

$$\frac{1}{n} \left[\sum_i \bar{w}_{t,i} h(\mathbf{z}_{t,i})^2 - \left(\sum_i \bar{w}_{t,i} h(\mathbf{z}_{t,i}) \right)^2 \right]. \quad (23.23)$$

分层重采样（stratified resampling）用独立分层均匀数消除层间抽样次数的随机波动；全方差公式表明，这会使条件方差不高于多项式法。**系统重采样**（systematic resampling）则共用一个随机偏移，容易实现，但选中位

置之间的相关性不再消失，不能把分层法的方差结论直接移用于它。两者的比较和系统法反例见 Douc 等人的分析⁶。

下面采用“传播、加权、输出估计、必要时重采样”的顺序。把提议选为状态转移得到**自举粒子滤波** (bootstrap particle filter)。另一种常见实现先重采样再传播，只要权重递推与所用祖先提议相匹配，也能正确工作；不能把两种顺序中的权重公式不加区分地混用。

⁶ R. Douc, O. Cappé, E. Moulines, *Comparison of Resampling Schemes for Particle Filtering* In 4th International Symposium on Image and Signal Processing and Analysis, 2005, pp. 64–69

算法 23.2 带阈值重采样的自举粒子滤波

输入： 状态空间模型、观测 $\mathbf{x}_{1:T}$ 、粒子数 n 、阈值 $\eta \in (0, 1]$

输出： 各时刻的滤波期望估计 $\hat{I}_{t,h}$

```

1: for  $t = 1, \dots, T$  do
2:   for  $i = 1, \dots, n$  do
3:     if  $t = 1$  then
4:       抽取  $\mathbf{z}_{1,i} \sim p(\mathbf{z}_1)$ , 置  $v_i = 1/n$ 
5:     else
6:       抽取  $\mathbf{z}_{t,i} \sim p(\mathbf{z}_t | \mathbf{z}_{t-1,i})$ 
7:       置  $v_i = \bar{w}_{t-1,i}$ 
8:     end if
9:      $w_{t,i} \leftarrow v_i p(\mathbf{x}_t | \mathbf{z}_{t,i})$ 
10:   end for
11:   若权重全零, 报告本轮退化并停止; 否则归一化为  $\bar{w}_{t,i}$ 
12:   输出  $\hat{I}_{t,h} = \sum_i \bar{w}_{t,i} h(\mathbf{z}_{t,i})$ 
13:   if  $1 / \sum_i \bar{w}_{t,i}^2 < \eta n$  且  $t < T$  then
14:     按  $\bar{w}_{t,1:n}$  抽取祖先索引  $a_{t,1:n}$ 
15:     同时复制旧  $\mathbf{z}_{t,a_{t,i}}$  为新  $\mathbf{z}_{t,i}$ , 置  $\bar{w}_{t,i} = 1/n$ 
16:   end if
17: end for

```

阈值中的 $1 / \sum_i \bar{w}_{t,i}^2$ 衡量当前权重集中程度，第 23.5.2 节会说明其含义和局限。输出本时刻估计后才重采样，是因为重采样会给当前估计增加随机性，多项式法的条件方差由式 (23.23) 给出；它的收益主要在于后续传播。若权重全零，不能把它们强行改成均匀权重并宣称完成了贝叶斯更新，应检查提议覆盖、观测模型或粒子数。

示例 23.2 二状态设备的粒子滤波 为单独观察时间递推，另设一个简化教学模型，不把它等同于前述四节点设备模型。 $Z_t \in \{0, 1\}$ 表示当前故障状态， $X_t \in \{0, 1\}$ 表示传感器读数。设

$$\begin{aligned}
 p(Z_1 = 1) &= 0.1, \\
 p(Z_t = 1 | Z_{t-1} = 1) &= 0.8, \quad p(Z_t = 1 | Z_{t-1} = 0) = 0.1, \\
 p(X_t = 1 | Z_t = 1) &= 0.8, \quad p(X_t = 1 | Z_t = 0) = 0.2.
 \end{aligned}$$

收到 $x_1 = x_2 = 1$ 。精确滤波给出

$$p(Z_1 = 1 | x_1 = 1) = \frac{0.1 \times 0.8}{0.1 \times 0.8 + 0.9 \times 0.2} = \frac{4}{13},$$

$$p(Z_2 = 1 | x_1 = 1) = 0.8 \frac{4}{13} + 0.1 \frac{9}{13} = \frac{41}{130},$$

$$p(Z_2 = 1 | x_1 = x_2 = 1) = \frac{0.8 \times 41}{0.8 \times 41 + 0.2 \times 89} = \frac{164}{253} \approx 0.648221.$$

假设上一轮已经得到等权粒子，传播到 $t = 2$ 的四个候选恰为 $(0, 1, 1, 0)$ 。其似然为 $(0.2, 0.8, 0.8, 0.2)$ ，归一化权重为 $(0.1, 0.4, 0.4, 0.1)$ ，故重采样前故障概率估计为 0.8。用系统重采样，取偏移 $u = 0.05$ ，四个定位点为 0.05, 0.30, 0.55, 0.80；累积权重为 0.1, 0.5, 0.9, 1，因而祖先索引为 $(1, 2, 3, 3)$ ，新粒子为 $(0, 1, 1, 1)$ 。这一次等权估计变成 0.75，并不恰好等于 0.8，更不等于精确答案。式 (23.22) 只保证对随机偏移再取期望后保持重采样前估计。

图 23.3 画出这个复制过程。第 3 个粒子虽有两个后代，但它们在复制瞬间完全相同，共享过去路径。后续随机转移可能使当前状态重新分散，已经丢失的历史路径却不会由复制自动恢复。**样本贫化** (sample impoverishment) 描述的是不同状态或祖先变少，与权重集中并非同一问题。过于频繁地重采样，尤其在状态噪声很小时，会使这类损失更严重；高维观测也可能让大多数粒子的似然同时接近零。




图 23.3 二状态例子的系统重采样。左侧为四个带权候选，右侧为等权后代；连线标明复制来源。候选 4 没有后代，候选 3 被复制两次。等权消除了权重差异，却没有增加状态或祖先的多样性。

若一次传播及似然计算成本分别为 C_{tr}, C_{obs} ，一轮基础滤波成本约为 $O(n(C_{tr} + C_{obs}))$ ，再加重采样成本。分层和系统法可沿累积权重单次扫描，

在 $O(n)$ 时间内完成；多项式法可用累积分布二分查找得到 $O(n \log n)$ 实现，也有预处理后线性总成本的实现。只保存当前 d 维状态需 $O(nd)$ 空间，保存所有粒子历史则随 T 增长。粒子数增加能改善固定时刻的近似，但不会自动保证长期平滑或高维滤波的效率。

23.4.3 Rao-Blackwell 化粒子滤波

如果潜状态的一部分在另一部分给定后能够解析处理，就没有必要把所有分量都粒子化。**Rao-Blackwell 化粒子滤波** (Rao-Blackwellized particle filtering, RBPF) 只采样难以积分的状态部分，同时为每条粒子路径维护其余状态的条件分布。设 $\mathbf{z}_t = (\mathbf{b}_t, \mathbf{u}_t)$ ，有

$$\begin{aligned} p(\mathbf{b}_{1:t}, \mathbf{u}_t | \mathbf{x}_{1:t}) \\ = p(\mathbf{b}_{1:t} | \mathbf{x}_{1:t}) p(\mathbf{u}_t | \mathbf{b}_{1:t}, \mathbf{x}_{1:t}). \end{aligned} \quad (23.24)$$

若第二项可用有限维参数精确递推，则粒子只表示 $\mathbf{b}_{1:t}$ ，每个粒子附带一份描述 $\mathbf{u}_t$ 的解析状态。估计 $h(\mathbf{b}_t, \mathbf{u}_t)$ 时，使用其条件期望

$$\hat{\Gamma}_{t,h}^{\text{RB}} = \sum_i \bar{w}_{t,i} \int h(\mathbf{b}_{t,i}, \mathbf{u}) p(\mathbf{u} | \mathbf{b}_{1:t,i}, \mathbf{x}_{1:t}) d\mathbf{u}.$$

解析积分也必须进入权重：观测似然应对 $\mathbf{u}_t$ 的条件预测分布积分，不能一边消去连续状态，一边仍使用某个随意选定连续状态的似然。

典型例子是给定离散模式 b_t 后，连续状态服从线性高斯模型。每条模式路径维护高斯均值与协方差，通过 Kalman 递推完成条件滤波；模式仍用粒子表示。用标量的一步更新说明这一计算：给定某条模式路径，连续状态预测分布为 $U_t \sim \mathcal{N}(m^-, v^-)$ ，观测满足 $X_t = U_t + \varepsilon_t$ ， $\varepsilon_t \sim \mathcal{N}(0, \sigma_x^2)$ 且独立。将两个高斯相乘并配方，可得

$$\begin{aligned} p(x_t | \mathbf{b}_{1:t}, \mathbf{x}_{1:t-1}) &= \mathcal{N}(x_t; m^-, v^- + \sigma_x^2), \\ k_t &= \frac{v^-}{v^- + \sigma_x^2}, \\ m_t &= m^- + k_t(x_t - m^-), \quad v_t = (1 - k_t)v^-. \end{aligned} \quad (23.25)$$

第一行用于粒子权重，后两行更新该粒子携带的连续状态条件分布。 k_t 是标量 Kalman 增益，控制当前观测对条件均值的修正幅度。

假设两个等先验模式分别给出 $U_t \sim \mathcal{N}(0, 1)$ 和 $\mathcal{N}(0, 4)$ ，共同观测噪声方差 $\sigma_x^2 = 1$ ，观测 $x_t = 1$ 。两模式的预测似然分别为 $\mathcal{N}(1; 0, 2) \approx 0.219696$ 和 $\mathcal{N}(1; 0, 5) \approx 0.161434$ ，归一化模式权重约为 0.576433, 0.423567。更新后的连续状态分别服从 $\mathcal{N}(0.5, 0.5)$ 和 $\mathcal{N}(0.8, 0.8)$ ，故混合均值约为 0.627070。整个运算没有抽取一个连续状态值，却保留了其条件不确定性；若再从这两个高斯中抽样估计均值，只会增加这一条件抽样带来的波动。

RBPF 的收益依赖确实存在可精确递推的条件结构。每个粒子携带协方差矩阵会增加内存和矩阵运算成本，模式路径本身也可能退化；使用扩展 Kalman 等近似滤波替代精确条件积分时，会额外引入近似误差，不能继续声称纯粹的 Rao-Blackwell 保证。全方差公式说明在相容条件化下移除随机性为何有利，但对相同运行时间下的完整粒子算法，仍须比较粒子数、重采样和解析运算成本。Doucet 等人的原始工作详细讨论了这一构造⁷。

⁷ A. Doucet, N. de Freitas, K. Murphy, S. Russell, *Rao-Blackwellised Particle Filtering for Dynamic Bayesian Networks* In *Proceedings of the Sixteenth Conference on Uncertainty in Artificial Intelligence*, 2000, pp. 176–183

23.5 算法分析

一种采样器可以保持正确目标，却在有限预算内给出不可靠答案；一个有限样本偏差的比值估计，也可以随样本数增长而一致。分析时需要分别问：估计的是哪个对象，哪个规模趋向无穷，什么条件支持极限，以及当前计算距该极限可能还有多远。

23.5.1 一致性、偏差与方差

独立直接采样的条件最清楚。对固定查询 h ，独立同分布与 $\mathbb{E}_p|h| < \infty$ 给出强一致性； $\mathbb{E}_p h^2 < \infty$ 进一步给出式 (23.3) 的方差与中心极限定理。对于有界指示函数，这些矩条件自动成立。对于 Cauchy 等重尾分布，某些后验均值本身就不存在，不能用更多样本把一个未定义的期望“算准”。 $n^{-1/2}$ 误差尺度也只描述随机计算误差，不包括模型失配。

重要性采样把这些矩条件移到了 q 下的加权函数。归一化目标的普通 IS 需要 rh 可积；有限方差与普通中心极限定理需要 $\mathbb{E}_q(rh)^2 < \infty$ 。SNIS 的一致性条件见式 (23.6) 之后。为了得到一个方便使用的 SNIS 中心极限定理，可以进一步要求 $\mathbb{E}_q w^2 < \infty$ 和 $\mathbb{E}_q (wh)^2 < \infty$ 。对两个样本均值使用联合中心极限定理，再对比值作一阶展开，得到

$$\begin{aligned} \sqrt{n}(\hat{I}_{h,n}^{\text{SNIS}} - I_h) &\xrightarrow{d} \mathcal{N}(0, v_h^{\text{IS}}), \\ v_h^{\text{IS}} &= \frac{\mathbb{E}_q[w^2(h - I_h)^2]}{Z_x^2}. \end{aligned} \quad (23.26)$$

关键的一阶随机量是 $w(h - I_h)$ ，不是单独的 w 。这解释了为什么同一组权重对于不同查询可能具有不同精度。

SNIS 的偏差也可由同一个比值展开看清。令 $Y = wh$ 、 $\mu_Y = \mathbb{E}_q Y = Z_x I_h$ ，把 $f(a, b) = a/b$ 在 (μ_Y, Z_x) 处展开到二阶。在足够高阶矩和分母尾部控制使期望余项为 $o(n^{-1})$ 的条件下，

$$\mathbb{E}[\hat{I}_{h,n}^{\text{SNIS}}] - I_h = \frac{I_h \text{Var}_q(w) - \text{Cov}_q(wh, w)}{nZ_x^2} + o(n^{-1}). \quad (23.27)$$

例如 $w \geq a > 0$ 且 $\mathbb{E}_q[w^4 + |wh|^4] < \infty$ ，是控制分母和展开余项的一组较

强充分条件。这个展开说明常见的 $O(n^{-1})$ 偏差从何而来；仅有可积性和支撑集覆盖时，不能无条件使用这个阶数。

MCMC 的极限变量是运行长度，而不是独立样本数。若核保持 p 并且正 Harris 常返，对 p 可积的 h ，从允许起点出发的时间平均收敛到 I_h 。非周期性另用于保证每一步的分布收敛；它并不是上述时间平均结论在所有情形下都必需的条件。若链从平稳分布启动，有限样本均值在期望存在时仍无偏，只是有相关性；实际从指定点启动并丢弃有限预热段后，通常仍有初始化偏差，预热长度本身不构成消除偏差的证明。

MCMC 中心极限定理还需额外条件。一组常用充分条件是**几何遍历性** (geometric ergodicity)，即到平稳分布的距离按几何速率衰减且允许系数依赖起点，再加 $\mathbb{E}_p |h|^{2+\delta} < \infty$ ，其中某个 $\delta > 0$ 。更具体地，可要求 $\|K^k(\mathbf{z}, \cdot) - p\|_{\text{TV}} \leq C(\mathbf{z})a^k$ ， $0 < a < 1$ ，并配合适当的 Harris 与初始状态条件。满足这些条件时，

$$\sqrt{n}(\hat{I}_{h,n} - I_h) \xrightarrow{d} \mathcal{N}(0, v_h^{\text{MC}}).$$

这些是充分条件而非所有算法的必要条件；仅有不变性、不可约性或一个看似稳定的样本均值，都不足以推出此中心极限定理。其证明需要控制长期依赖，可通过再生结构或 Poisson 方程完成，本章不展开一般状态空间的证明⁸。

SMC 的样本数极限又不同：通常先固定一个有限时刻 t ，再令粒子数 $n \rightarrow \infty$ 。为看清这一区别，可以考察一组较强而易检查的充分条件：初始粒子独立来自模型初始分布，传播使用正确的 Markov 转移；每个固定时刻的观测似然作为状态函数有正下界和有限上界；测试函数 h 有界；采用固定日程的多项式重采样。此时滤波积分估计一致，并满足适当的 $\sqrt{n}$ 中心极限定理。一般提议需要相应的重要性权重矩条件，其他重采样方案和自适应日程也要满足各自的额外条件，不能只检查后代数是否条件无偏。

固定时刻一致性的证明思路是归纳。给定旧粒子后，新传播条件独立，因此对有界函数，传播抽样相对于其条件均值的方差为 $O(1/n)$ 。条件均值是旧经验分布对转移后函数的积分，由归纳假设收敛。乘有界似然并除以远离零的归一化常数，仍保持收敛；多项式重采样再增加一个由式 (23.23) 控制的 $O(1/n)$ 条件方差。固定步数下反复使用这三个步骤便得到一致性。这是证明纲要，中心极限定理还需追踪每一代随机扰动如何传播，渐近方差包含历史各代贡献，而不只是当前粒子的样本方差⁹。

上述证明中的误差常数可以随 t 迅速增大。固定 n 让时间无限延长，与固定 t 让 n 趋向无穷，是不同的极限；要获得时间一致误差界，通常还需状态转移的遗忘或混合性质，以及适当的似然控制。归一化粒子滤波均值一般有有限 n 偏差。标准自举滤波在正确权重、每轮多项式重采样等条件

⁸ G. O. Roberts, J. S. Rosenthal, *General State Space Markov Chains and MCMC Algorithms* In Probability Surveys, 2004, vol. 1, pp. 20–71

⁹ N. Chopin, *Central Limit Theorem for Sequential Monte Carlo Methods and Its Application to Bayesian Inference* In The Annals of Statistics, 2004, vol. 32, no. 6, pp. 2385–2411

下，其逐时预测似然估计的乘积可无偏估计边缘似然，但这并不意味着归一化滤波均值也无偏。每个估计量都应针对自身结构判断。

23.5.2 有效样本量与收敛诊断

输出文件中的样本条数不等于用于回答某个查询的信息量。**有效样本量** (effective sample size, ESS) 试图用独立样本的尺度描述估计精度，但不同场合使用的 ESS 不是同一个量，尤其不能把权重 ESS 与自相关 ESS 混为一谈。

对归一化非负权重，常用**权重有效样本量** (weight-based ESS)

$$n_{\text{eff}}^w = \frac{1}{\sum_i \bar{w}_i^2} = \frac{(\sum_i w_i)^2}{\sum_i w_i^2}, \quad 1 \leq n_{\text{eff}}^w \leq n. \quad (23.28)$$

上下界来自非负性和 Cauchy-Schwarz 不等式：等权时等于 n ，一个权重占满总和时等于 1。若候选确实独立来自固定 q 且 $\mathbb{E}_q w^2 < \infty$ ，大数定律还给出

$$\frac{n_{\text{eff}}^w}{n} \rightarrow \frac{(\mathbb{E}_q w)^2}{\mathbb{E}_q w^2} = \frac{1}{1 + \text{CV}_q(w)^2},$$

其中 $\text{CV}_q(w)$ 为权重的标准差与均值之比。因此这个指标准确描述了已抽到权重的集中程度，却不是对每个 h 都成立的方差等价样本数。真正的 IS 渐近方差还含有式 (23.26) 中的 $(h - I_h)^2$ 。

表 23.1 中， $n_{\text{eff}}^w = 2.51^2 / (0.01^2 + 0.9^2 + 0.9^2 + 0.7^2) \approx 2.986$ 。这个数不能告诉我们是是否遗漏了重要的罕见状态。粒子滤波例子重采样前的权重 ESS 为 $1 / (0.1^2 + 0.4^2 + 0.4^2 + 0.1^2) \approx 2.941$ ，重采样后立即变成 4；但图 23.3 已经显示祖先反而减少。SMC 中这一指标主要用于决定何时重新分配粒子资源，不用于证明滤波误差已经足够小。

MCMC 常常所有样本等权，若机械使用式 (23.28)，总会得到 n 。它遗漏了重复停留和缓慢移动产生的时间相关。设链已平稳， $0 < \sigma_h^2 = \text{Var}_p(h) < \infty$ ，令 $\rho_h(\ell)$ 为 $h(\mathbf{z}^{(k)})$ 与 $h(\mathbf{z}^{(k+\ell)})$ 的相关系数。展开样本均值的协方差和，有

$$\text{Var}(\hat{I}_{h,n}) = \frac{\sigma_h^2}{n} \left[1 + 2 \sum_{\ell=1}^{n-1} \left(1 - \frac{\ell}{n} \right) \rho_h(\ell) \right]. \quad (23.29)$$

滞后 ℓ 的样本对恰有 $n - \ell$ 个，因而出现括号中的系数。若自相关绝对可和，定义**积分自相关时间** (integrated autocorrelation time)

$$\tau_h = 1 + 2 \sum_{\ell=1}^{\infty} \rho_h(\ell), \quad v_h^{\text{MC}} = \sigma_h^2 \tau_h, \quad n_{\text{eff},h}^{\text{MC}} = \frac{n}{\tau_h}. \quad (23.30)$$

这里假定 $0 < \tau_h < \infty$ ；还需前述中心极限定理条件，才能据此使用正态近似误差区间。自相关和本身不是中心极限定理的充分证明。 τ_h 依赖函数 h ，

故均值、尾概率和不同坐标通常有不同 ESS；负相关还可能使 $\tau_h < 1$ ，此时 ESS 大于 n ，并不矛盾，因为它匹配的是估计方差而非独立点的实际数量。

例如平稳自回归序列的 $\rho_h(\ell) = 0.9^\ell$ ，则 $\tau_h = 1 + 2(0.9/0.1) = 19$ ，10000 次迭代对该查询只有约 526 个独立样本的渐近精度。对前述强相关高斯的 Gibbs 坐标， $\rho = 0.99$ 给出的每轮相关系数为 0.9801，对应 $\tau_h = (1 + 0.9801)/(1 - 0.9801) \approx 99.50$ 。两个例子都说明，高接受率和长样本文件不能替代误差分析。简单地每隔若干步保留一个点虽然降低保留序列的相关性，也丢弃了已付费的计算；除非有存储或后续处理约束，稀疏保留不是改善采样效率的通用办法。

实际估计自相关和时不能无限相加带噪声的样本相关系数，需要截断规则、批均值或谱方差估计。用 $\sqrt{\hat{c}_h^{\text{MC}}/n}$ 报告具体查询的 MCSE，比只报告全局 ESS 更有意义。独立 SNIS 在相应矩条件下可用 $[\sum_i \bar{w}_i^2 (h_i - \hat{I}_h)^2]^{1/2}$ 估计标准误，其中 $h_i = h(\mathbf{z}_i)$ ；这个公式不能直接用于共享祖先的粒子系统。SMC 可通过多次独立运行整个粒子滤波比较估计波动，或采用专门的粒子方差估计。

单条链可能在一个局部区域内看起来很稳定。多链诊断从分散的有效初值运行若干条独立链，比较链内与链间变化。 **$\hat{R}$ 诊断** (R-hat diagnostic) 用两种变化尺度之比发现不同链尚未探索相同分布的迹象。设共有 m 条链，每条保留 n 个函数值，链均值为 $\bar{h}_j$ ，链内样本方差为 s_j^2 ，总体均值为 $\bar{h}$ 。经典形式为

$$W = \frac{1}{m} \sum_{j=1}^m s_j^2, \quad B = \frac{n}{m-1} \sum_{j=1}^m (\bar{h}_j - \bar{h})^2, \quad (23.31)$$

$$\hat{V} = \frac{n-1}{n} W + \frac{B}{n}, \quad \hat{R} = \sqrt{\hat{V}/W}.$$

当链间差异远大于链内波动时， $\hat{R}$ 会偏大。若所有链完全不动导致 $W = 0$ ，该比值没有可用的通常解释，而不能被当作已经收敛。

现代实现通常先把每条链分成前后两半，再将合并样本的秩映射为正态分位数，计算秩归一化的分裂 $\hat{R}$ ；还对“样本到合并中位数的绝对偏差”重复同样计算，并取两者的较大值。分裂有助于发现链内漂移，秩变换缓解重尾矩不稳定，折叠后的绝对偏差有助于发现不同链的尺度差异。相应地，主体 ESS 根据秩变换后的序列衡量中心区域的探索，尾部 ESS 考察分位点附近的指示函数；它们不能自动代替原始均值或任意非线性查询的 MCSE。常用的 $\hat{R} < 1.01$ 是经验筛查标准，不是数学上的收敛证书¹⁰。

诊断应同时看多链轨迹、秩分布、目标相关函数的 MCSE、主体与尾部 ESS；HMC 还应检查大能量误差、积分失败和长时间拒绝。若全部链都在同一个未被识别的模式里活动，这些指标仍可能看起来正常。改变有效初

¹⁰ A. Vehtari, A. Gelman, D. Simpson, B. Carpenter, P.-C. Bürkner, *Rank-Normalization, Folding, and Localization: An Improved $\hat{R}$ for Assessing Convergence of MCMC* In *Bayesian Analysis*, 2021, vol. 16, no. 2, pp. 667–718

值、增加预算、检查模型几何，并与可解析特例或独立算法比较，可以暴露部分遗漏；没有任何一个基于有限输出的诊断量能够单独证明已经遍历整个目标。

23.5.3 方法选择与计算边界

选择方法应从能计算什么出发。若已有准确且廉价的直接采样器，独立平均通常最容易分析和并行；只有联合采样器而证据并不稀有时，拒绝采样能得到独立后验样本。若能够构造充分覆盖目标的提议，重要性采样便于并行且可估计归一化常数，但应优先检查权重尾部，而非仅拟合后验峰附近。

若只有未归一化密度及局部条件，MCMC 可以避免全局提议的要求。满条件易抽样且相关适中时，Gibbs 利用图结构获得低成本更新；强相关变量应考虑分块、折叠或重新参数化。连续密度可微时，HMC 能用较贵的一次轨迹换取更远移动，但高维离散结构、多峰分离或复杂约束可能需要其他构造。若目标随新观测递推，粒子滤波直接复用过去计算；存在条件线性高斯部分时，RBPF 可以把预算集中到真正需要采样的状态。

实际比较应固定查询与计算预算。一个每步便宜但高度相关的链，可能比一个每步较贵的链花更多时间才能达到同样 MCSE；独立提议也可能因极端权重而在单位时间内信息很少。因此应比较具体查询的 MCSE 随时间变化，或该查询的 ESS 每秒，并把预热、提议构造、梯度和解析积分计入成本。模型中的条件独立性帮助局部计算，却不保证后验中的统计相关很弱。

第 22 章的变分推断用可优化分布族近似后验，采样则用随机经验表示近似后验积分。两者的差异不是“有偏”与“无偏”的简单二分，表 23.3 列出需要分别判断的方面。

采样也可与变分结合，例如把拟合的变分分布作为重要性提议或独立 MH 提议。但校正是否有效仍由支撑集与权重决定：一个遗漏后验尾部的提议不会因被冠以“变分初始化”就获得良好采样性质。反过来，在一组小规模、可高精度采样的问题上检查变分误差，也有助于理解快速近似的边界。这里不存在对所有模型都最优的推断器，只有在目标、计算能力与误差要求明确以后才可比较的方案。

23.6 本章小结

采样推断把后验概率和期望转成样本的统计量，但随机性本身不提供正确性。独立候选需要正确的目标变换、接受规则或权重；Markov 链需要保持目标且能够访问其重要区域；粒子系统需要在递推中正确传播、加权和分配后代。设备报警例子给出的精确后验说明，同一批看似合理的候选，若

方面	采样近似	变分近似
渐近目标	在相应覆盖、矩与遍历条件下，可逼近原后验积分	受分布族与目标函数限制，充分优化后仍可能有近似误差
有限预算	有抽样波动，SNIS 与非平稳 MCMC 等还可能有偏差	有分布族误差、优化误差，随机优化也有波动
后验覆盖	漏模态、权重退化或慢混合会破坏有限样本覆盖	某些族与散度倾向集中于局部区域，但不能概括所有变分方法
并行与规模	独立候选、多链和粒子可并行；单链有顺序依赖，重采样需同步	易利用小批量和摊销网络，但依赖相应模型与优化结构
精度判断	查询相关的标准误与多种诊断并用	目标函数改善不等于所有后验查询都已准确

表 23.3 在同一后验推断任务上比较采样与变分。渐近保证都有适用条件，有限预算下均需检查遗漏的后验结构。

缺少必要修正，就可能回答另一个概率问题。

HMC 展示了这种分工的一个完整实例：动量刷新保持扩展分布并改变运动方向，可逆保体积构造可配对的远距离提议，Metropolis 步骤校正积分造成的能量误差。粒子滤波则表明，重新分配权重与增加信息不是同一件事；复制高权重粒子有利于后续计算，却可能损失状态与祖先的多样性。

可靠的结论必须与其极限条件和查询对象一起报告。独立样本的有限矩、重要性采样的覆盖与加权矩、MCMC 的遍历与混合条件、SMC 的固定时间粒子数极限，各自支撑不同的误差分析。权重 ESS 反映贡献集中，自相关 ESS 匹配特定函数的长期方差，多链诊断帮助发现探索不一致；它们都不能把有限输出变成收敛证明。用模型结构降低计算成本，再用可复核例子、查询相关标准误和针对失效模式的诊断检查结果，才使样本成为可信的近似推断工具。

到这里，精确消元、变分优化和随机采样都在给定模型下回答查询。若局部概率本身还未知，后验期望便会进入参数更新，推断误差也可能影响学习结果。第 24 章接着说明这种依赖何时出现，以及观测完整且不含潜变量时为什么有些模型能免去内层推断。

参数学习

在设备故障模型 $F \rightarrow H \rightarrow A \leftarrow S$ 中，图告诉我们怎样组织故障、过热、报警和传感器失灵之间的概率关系，却没有告诉我们故障率是多少。此前的推断问题把这些概率视为已知；现在给定一批设备记录，要反过来确定它们。若应测字段都已记录且模型不含潜变量，某些参数可以通过计数或回归得到；只要模型主动引入了未观测状态，或者应测字段实际漏记，学习就可能需要在参数更新中调用推断。

本章固定图结构和局部分布的形式，沿两条彼此交叉的轴组织参数学习。数据可见性轴区分观测完整且不含潜变量、观测完整但含潜变量，以及观测字段发生缺失；估计方式轴区分输出一个参数点与保留参数后验分布。图的因子组织和归一化范围决定即使没有未观测变量时需要什么计算，未观测变量又决定是否必须恢复后验统计量。分清这些对象，才能判断算法实际优化或近似了什么，以及所得结果保留了哪种不确定性。

24.1 参数学习的定义

设 $\mathcal{G} = (V, E)$ 为固定图， $d = |V|$ 。把全部节点随机变量记为 $\mathbf{W} = (W_1, \dots, W_d)^\top$ ，并按观测状态拆成数据字段 $\mathbf{X}$ 与模型主动设置的潜变量 $\mathbf{Z}$ ，即在固定排列下 $\mathbf{W} = (\mathbf{X}^\top, \mathbf{Z}^\top)^\top$ 。局部条件分布或势函数由参数向量 $\theta \in \Theta$ 控制。这里 Θ 不仅规定参数维度，还包括概率和为 1、方差为正、配分函数有限等约束。**参数学习**（parameter learning）是在这一模型族内，利用记录确定参数点或参数后验的过程；图的边是否存在、潜变量有哪些以及局部分布属于哪一族，在本章均先行确定。

观测变量（observed variable）是在当前数据获取设计中直接记录的模型变量，**潜变量**（latent variable）则是模型为了表达未观测状态而主动引入的随机量。**缺失值**（missing value）不是另一类随机变量，而是本应观测的数据字段在某条记录中没有取得的取值。参数 θ 控制这些变量的分布；在 MLE 与 MAP 中它是未知但固定的优化量，在分布估计中才通过先验和后验表示其不确定性。变量的观测状态、数据单元是否缺失与参数是否未知，因而是三个不同问题。

本章所说**观测完整**，只表示 $\mathbf{X}$ 中按设计应观测的字段没有缺失，不表示模型中的每个随机变量都可见。由此，观测完整且不含潜变量时，每条记录给出全部模型变量；观测完整但含潜变量时， $\mathbf{X}$ 没有漏记， $\mathbf{Z}$ 仍按模型设定不可见；观测缺失时， $\mathbf{X}$ 还要按实际缺失模式拆成已观测部分与缺失部分。潜变量与缺失部分在计算上都要被求和或积分，但只有缺失部分还要求解释记录为何没有取得。

以观测完整且不含潜变量的独立记录为例，数据集记为 $\mathcal{D} = \{\mathbf{x}_j\}_{j=1}^n$ ，其中 $x_{j,i}$ 是第 j 条记录中节点 i 的取值。默认不同记录在给定共同参数后独立同分布，因而 $p_{\theta}(\mathcal{D}) = \prod_j p_{\theta}(\mathbf{x}_j)$ 。这不要一条记录内部的节点独立；图模型恰好用来描述这种内部依赖。若记录是同一台设备的连续时间观测，不能直接当作独立样本，须用第 28 章的序列模型或另行处理时间相关性。

局部分布不同，不意味着其参数一定各自独立。**参数共享** (parameter sharing) 让多个节点或多条记录使用同一个未知参数，例如同型号传感器共用误报率。固定图结构并未排除共享；共享参数必须同时接受所有相关局部项的约束，不能在每个节点上分别估计出不同的数再直接拼接。

要比较候选参数，需要先选定目标。**最大似然估计** (maximum likelihood estimation, MLE) 选择使已经观测到的数据最可能的参数；**最大后验估计** (maximum a posteriori estimation, MAP) 还利用参数先验，选择后验密度最大的点。令 $\ell(\theta) = \log p_{\theta}(\mathcal{D})$ ，在最优解存在时，

$$\begin{aligned}\hat{\theta}_{\text{ML}} &\in \arg \max_{\theta \in \Theta} \ell(\theta), \\ \hat{\theta}_{\text{MAP}} &\in \arg \max_{\theta \in \Theta} \{\ell(\theta) + \log p(\theta)\}.\end{aligned}\tag{24.1}$$

这里似然是固定数据后关于参数的函数，不是参数的概率分布。MAP 的密度及其众数相对于所选参数坐标和基准测度定义，换用非线性参数化时不能忽略 Jacobian。最大值也未必唯一，甚至可能只有上确界。

MLE 与 MAP 都只返回目标的一个最优参数点。MAP 虽然使用先验，却不等于保留参数不确定性。若数据不足以排除多组参数，**基于分布估计的参数学习**则保留

$$p(\theta | \mathcal{D}) = \frac{p_{\theta}(\mathcal{D})p(\theta)}{\int_{\Theta} p_{\vartheta}(\mathcal{D})p(\vartheta) d\vartheta},\tag{24.2}$$

即按照先验与数据为不同参数分配后验权重，前提是分母有限且为正。这里保留的是参数 θ 的后验，不是固定参数下模型变量 $\mathbf{X}, \mathbf{Z}$ 的后验；后者在含未观测变量时只是完成参数学习所需的推断对象。后验均值 $\mathbb{E}[\theta | \mathcal{D}]$ 在相应平方损失下是一个贝叶斯点估计，但它通常既不是 MLE，也不是 MAP，更不等于整个后验。

估计准则还要与预测对象对应。把一条记录分成输入 $\mathbf{x}_j$ 与输出 $\mathbf{y}_j$ 后，

联合训练与条件训练分别使用

$$\begin{aligned}\ell_{\text{joint}}(\theta) &= \sum_j \log p_{\theta}(\mathbf{x}_j, \mathbf{y}_j), \\ \ell_{\text{cond}}(\theta) &= \sum_j \log p_{\theta}(\mathbf{y}_j | \mathbf{x}_j).\end{aligned}$$

前者同时约束输入和输出的分布；后者把输入当作给定条件，不要求为输入建立概率模型。这一区别与有向或无向的因子组织不是同一个分类维度。若两种训练共用某个联合模型的参数，由于

$$\log p_{\theta}(\mathbf{x}, \mathbf{y}) = \log p_{\theta}(\mathbf{y} | \mathbf{x}) + \log p_{\theta}(\mathbf{x}),$$

两种目标一般会选择不同的参数。第 24.2 至 24.4 节先沿数据可见性轴讨论 MLE 与 MAP 点估计，第 24.5 节再沿分布估计轴说明怎样保留 $p(\theta | \mathcal{D})$ ；这两条轴可以组合，而不是前后互斥的学习阶段¹。

¹ D. Koller, N. Friedman, *Probabilistic Graphical Models: Principles and Techniques*, MIT Press, 2009

24.2 观测完整且不含潜变量的参数学习

本节固定所有模型变量都已观测，比较三类图模型的 MLE 与 MAP 点估计。区别不在于数据是否完整，而在于因子怎样组织及概率对什么对象归一化：有向图的节点条件分布逐个局部归一化，联合无向图的势函数乘积对全部模型变量全局归一化，条件无向图则在每个给定输入下只对输出变量归一化。

24.2.1 有向图模型

对有向图，联合分布已经写成局部条件分布的乘积。因此，把乘积取对数，再对样本求和，就得到

$$\begin{aligned}\ell(\theta) &= \sum_{j=1}^n \sum_{i=1}^d \log p_{\theta_i}(x_{j,i} | \mathbf{x}_{j,\text{pa}(i)}) \\ &= \sum_{i=1}^d \ell_i(\theta_i).\end{aligned}\tag{24.3}$$

若不同节点参数块没有共享约束，且 $\Theta = \prod_i \Theta_i$ ，最大化每个 ℓ_i 就能最大化总似然。这个结论来自目标的可加性和参数空间的可分离性，两者缺一不可。父节点之间即使相关，也不妨碍在本节所有节点均已观测的条件下，利用它们的实测取值拟合子节点。

对离散节点，**条件概率表** (conditional probability table, CPT) 逐行列出每种父节点配置下的子节点分布。设 X_i 有 r_i 个状态，以 $\mathbf{a}$ 索引其父节点的取值配置。用 $\theta_{i,\mathbf{a},k}$ 表示该配置下 $X_i = k$ 的条件概率，约束为 $\theta_{i,\mathbf{a},k} \geq 0$

及 $\sum_k \theta_{i,a,k} = 1$ 。把相同局部事件的出现次数归并，得到

$$\begin{aligned} N_{i,a,k} &= \sum_{j=1}^n \mathbf{1}\{x_{j,i} = k, \mathbf{x}_{j,\text{pa}(i)} = \mathbf{a}\}, \\ N_{i,a} &= \sum_{k=1}^{r_i} N_{i,a,k}, \quad \ell_i = \sum_a \sum_{k=1}^{r_i} N_{i,a,k} \log \theta_{i,a,k}. \end{aligned} \quad (24.4)$$

这些计数是当前局部模型的**充分统计量** (sufficient statistic)：给定它们以后，原始记录的排列不再影响关于参数的似然。根节点只有一个空的父配置，其计数就是通常的类别频数。

固定一行 a ，在内部解上加入约束项 $\lambda(1 - \sum_k \theta_{i,a,k})$ 。对 $\theta_{i,a,k}$ 求导得到 $N_{i,a,k}/\theta_{i,a,k} = \lambda$ ，再对 k 求和得到 $\lambda = N_{i,a}$ 。允许零计数对应边界解，并约定 $0 \log 0 = 0$ ，可得

$$\hat{\theta}_{i,a,k,\text{ML}} = \frac{N_{i,a,k}}{N_{i,a}}, \quad N_{i,a} > 0. \quad (24.5)$$

若 $N_{i,a} = 0$ ，该行的似然为常数，数据不能识别其概率， $0/0$ 不是估计值。若强制所有概率严格为正，某些含零计数的行可能只有趋近边界的上确界，而没有内部 MLE。

少量记录中的零频数并不意味着某事件永远不可能发生。对每行引入**狄利克雷先验** (Dirichlet prior)，即在概率单纯形上为整行概率分配先验权重：

$$p(\theta_{i,a}) \propto \prod_{k=1}^{r_i} \theta_{i,a,k}^{\alpha_{i,a,k}-1}, \quad \alpha_{i,a,k} > 0.$$

把对数先验加入局部对数似然，仍可逐行求 MAP。记 $\alpha_{i,a,0} = \sum_k \alpha_{i,a,k}$ ；当所有 $\alpha_{i,a,k} + N_{i,a,k} > 1$ 时，内部众数为

$$\hat{\theta}_{i,a,k,\text{MAP}} = \frac{N_{i,a,k} + \alpha_{i,a,k} - 1}{N_{i,a} + \alpha_{i,a,0} - r_i}. \quad (24.6)$$

若条件不满足，应另行分析边界和众数是否唯一，不能照套公式。特别地，均匀狄利克雷先验的内部 MAP 与 MLE 相同；常说的“加一平滑”对应后验均值，不是该先验的 MAP，完整后验及后验均值留到第 24.5.1 节。

下面的设备记录用于连接后续计算。它们是人工构造的数据，不是实际设备统计，也不要求样本频率等于前面章节给定的教学概率。表 24.1 列出 20 条完整记录在 (F, H) 上的边缘计数； A, S 的记录不参与这里展示的两个局部参数块。

由计数可得 $\hat{p}(F = 1) = 5/20 = 0.25$ ，而 $\hat{p}(H = 1 | F = 1) = 4/5 = 0.8$ 、 $\hat{p}(H = 1 | F = 0) = 2/15$ 。若只对故障率 $\pi = p(F = 1)$ 使用 Beta(2, 2) 先验，即二元狄利克雷先验，则 MLE 为 $1/4$ ，MAP 为 $6/22 = 3/11 \approx 0.2727$ 。

故障状态	$H = 1$	$H = 0$	合计
$F = 1$	4	1	5
$F = 0$	2	13	15
合计	6	14	20

表 24.1 人工构造的局部计数，所有观测字段均无缺失。每列与每行都有明确分母，可分别复核根节点故障率和给定故障状态的过热率。

先验改变了点估计目标；它怎样产生完整参数后验以及为何后验均值又不同，将在第 24.5.1 节回到同一组计数。

连续节点也能利用局部分解。对线性高斯条件分布，设父节点数为 m_i ，将截距与父节点组成 $\mathbf{u}_{j,i} = (1, \mathbf{x}_{j,\text{pa}(i)}^\top)^\top$ ，并令

$$X_i | \mathbf{X}_{\text{pa}(i)} \sim \mathcal{N}(\boldsymbol{\beta}_i^\top \mathbf{u}_i, \sigma_i^2).$$

去掉与参数无关的常数，局部负对数似然为

$$-\ell_i = \frac{n}{2} \log \sigma_i^2 + \frac{1}{2\sigma_i^2} \sum_{j=1}^n (x_{j,i} - \boldsymbol{\beta}_i^\top \mathbf{u}_{j,i})^2.$$

将 $\mathbf{u}_{j,i}^\top$ 按样本顺序堆叠为设计矩阵 $\mathbf{U}_i$ ，它有 n 行、 $m_i + 1$ 列。响应向量为 $\mathbf{y}_i = (x_{1,i}, \dots, x_{n,i})^\top$ 。固定正方差，对回归系数求导得到正规方程；在 $\mathbf{U}_i$ 列满秩且残差平方和为正时，

$$\begin{aligned} \hat{\boldsymbol{\beta}}_i &= (\mathbf{U}_i^\top \mathbf{U}_i)^{-1} \mathbf{U}_i^\top \mathbf{y}_i, \\ \hat{\sigma}_i^2 &= \frac{1}{n} \|\mathbf{y}_i - \mathbf{U}_i \hat{\boldsymbol{\beta}}_i\|_2^2. \end{aligned} \quad (24.7)$$

MLE 方差的分母是 n ，不是用于无偏残差方差估计的 $n - m_i - 1$ 。设计矩阵秩亏时系数可能不唯一；残差全为零且方差可以任意趋近 0 时，似然无界。数值求解宜用 QR 等分解而不显式求逆。至此，完整有向模型的学习化成了各节点的计数或回归，困难主要在局部数据是否充足、参数是否受共享约束，而不在全局推断。

24.2.2 联合无向图

无向模型的势函数也分布在局部，但它们并不各自归一化。考虑固定支持集 $\mathcal{X}$ 上的正指数族模型

$$\begin{aligned} p_\theta(\mathbf{x}) &= h(\mathbf{x}) \exp\{\boldsymbol{\theta}^\top \mathbf{T}(\mathbf{x}) - A(\boldsymbol{\theta})\}, \\ A(\boldsymbol{\theta}) &= \log Z(\boldsymbol{\theta}), \\ Z(\boldsymbol{\theta}) &= \int_{\mathcal{X}} h(\mathbf{x}) e^{\boldsymbol{\theta}^\top \mathbf{T}(\mathbf{x})} d\mu(\mathbf{x}). \end{aligned} \quad (24.8)$$

$\mathbf{T}$ 收集团上的充分统计量, h 是与参数无关的基准因子, μ 在离散情形取计数测度, 在连续情形取相应基准测度。要求 $0 < Z(\theta) < \infty$ 。令 $\bar{\mathbf{T}} = n^{-1} \sum_j \mathbf{T}(\mathbf{x}_j)$, 平均对数似然中与参数有关的部分为 $\theta^\top \bar{\mathbf{T}} - A(\theta)$ 。

为什么局部势的变化会引入全局计算? 在可以交换微分与积分的条件下, 对归一化项求导得到

$$\begin{aligned}\nabla_\theta A(\theta) &= \frac{1}{Z(\theta)} \int h(\mathbf{x}) e^{\theta^\top \mathbf{T}(\mathbf{x})} \mathbf{T}(\mathbf{x}) d\mu(\mathbf{x}) \\ &= \mathbb{E}_{p_\theta}[\mathbf{T}(\mathbf{X})], \\ \frac{1}{n} \nabla_\theta \ell(\theta) &= \bar{\mathbf{T}} - \mathbb{E}_{p_\theta}[\mathbf{T}(\mathbf{X})].\end{aligned}\tag{24.9}$$

有限离散支持下可逐项求导; 连续情形可由参数邻域内的可积支配函数等正则条件保证交换。梯度比较了数据实际呈现的统计量与模型预期的统计量: 模型对某种相互作用估计不足, 就提高它的权重; 估计过多, 就降低权重。最优内部点满足矩匹配, 但数据矩落在可实现矩集合的边界时, 有限参数 MLE 可能不存在。

再求一次导数, 得到 $\nabla^2 A = \text{Cov}_{p_\theta}[\mathbf{T}(\mathbf{X})]$, 所以线性自然参数下的对数似然是凹函数。充分统计量若有冗余, 协方差可能奇异, 凹性并不保证参数唯一。这一几何性质不能照搬到任意神经网络势函数的参数上; 非线性参数化一般会改变优化问题的曲率。指数族与矩匹配的关系可回顾第 22 章²。

一个只有两个节点的例子可以直接核验梯度。设 $X_1, X_2 \in \{-1, 1\}$, $p_\theta(x_1, x_2) \propto e^{\theta x_1 x_2}$ 。同号和异号各有两个配置, 因此 $Z(\theta) = 2e^\theta + 2e^{-\theta} = 4 \cosh \theta$, 模型期望为 $\mathbb{E}_\theta[X_1 X_2] = \tanh \theta$ 。若 10 条记录中有 8 条同号、2 条异号, 则经验统计量为 0.6, 平均似然梯度为 $0.6 - \tanh \theta$ 。令它为零, 得到 $\hat{\theta} = \text{arctanh}(0.6) = \log 2$; 代回模型, 同号概率 $e^\theta / (e^\theta + e^{-\theta}) = 0.8$, 恰好匹配记录。

这个例子只有四种状态, 可以枚举。一般图上, 直接计算 Z 或模型期望可能需要高维求和; 计算梯度不一定要显式给出 Z 的数值, 却仍要完成同等重要的概率推断。处理这一困难时, 必须区分保留似然但近似计算, 与改变学习准则。

保留似然的路线以式 (24.9) 为出发点。用 MCMC 产生近似服从 p_θ 的样本, 再用样本均值估计模型期望; 链混合不足带来偏差, 样本相关性降低有效样本量。也可以通过变分推断取得近似边缘分布, 计算所需的局部统计量。若使用的是某个近似对数配分函数 $\tilde{A}$ 的梯度, 实际优化的便是 $\theta^\top \bar{\mathbf{T}} - \tilde{A}(\theta)$ 。仅把任意近似边缘塞进梯度, 并不自动保证它是某个一致目标的梯度, 更没有精确似然单调增加的保证。

另一条路线主动更换准则。**伪似然** (pseudolikelihood) 把每个节点在

² M. J. Wainwright, M. I. Jordan, *Graphical Models, Exponential Families, and Variational Inference* In Foundations and Trends in Machine Learning, 2008, vol. 1, no. 1–2, pp. 1–305

其余节点已知时的条件概率相乘，用一组容易归一化的预测问题替代联合密度拟合。沿用第 18.2.2 节的邻居集合 $N(i)$ ，正无向模型满足

$$\ell_{\text{PL}}(\theta) = \sum_{j=1}^n \sum_{i=1}^d \log p_{\theta}(x_{j,i} | \mathbf{x}_{j,N(i)}). \quad (24.10)$$

固定邻居后，不含 i 的势函数与全局 Z 一起约掉，只需对 X_i 归一化。二值节点只涉及两个候选值，因此常比全局求和容易。不过，这些条件概率的乘积一般不是原数据的联合概率，不能把伪似然值当作联合预测对数似然报告。

复合似然 (composite likelihood) 进一步组合若干低维边缘或条件似然，其对数形式是这些局部对数似然按固定非负权重相加，伪似然是其中一个特例。选择可计算的条件块可以避开全局归一化；若选择的边缘块本身仍难以求出，则并没有消除推断困难。在模型正确、所用局部项能够识别参数且满足通常的估计正则条件时，这类估计可以一致，但有限样本解和统计效率一般不同于 MLE。其标准误也不能不加修正地套用完整似然的信息矩阵公式³。

若模型只给出非归一化密度，还可以把估计转化为区分数据与已知噪声的分类任务。**噪声对比估计** (noise-contrastive estimation, NCE) 选择已知且覆盖数据支持的噪声密度 p_N ，对每个数据样本抽取 ν 个噪声样本，这里 ν 为正整数。在合并后的样本中， $D = 1$ 表示来自数据， $D = 0$ 表示来自噪声，来源先验为 $P(D = 1) = 1/(1 + \nu)$ 、 $P(D = 0) = \nu/(1 + \nu)$ 。若真实数据密度为 p_* ，则贝叶斯公式给出

$$\begin{aligned} P(D = 1 | \mathbf{x}) &= \frac{p_*(\mathbf{x})P(D = 1)}{p_*(\mathbf{x})P(D = 1) + p_N(\mathbf{x})P(D = 0)} \\ &= \frac{p_*(\mathbf{x})}{p_*(\mathbf{x}) + \nu p_N(\mathbf{x})}. \end{aligned}$$

因此，分母中的 ν 来自两类样本的数量比例。用 $\tilde{p}_{\theta,c}(\mathbf{x}) = \exp\{f_{\theta}(\mathbf{x}) + c\}$ 拟合数据密度，并把负对数归一化常数作为额外标量 c 学习，就得到来源分类概率模型

$$a_{\theta,c}(\mathbf{x}) = \frac{\tilde{p}_{\theta,c}(\mathbf{x})}{\tilde{p}_{\theta,c}(\mathbf{x}) + \nu p_N(\mathbf{x})}.$$

$a_{\theta,c}(\mathbf{x})$ 是给定样本后“它来自数据”的概率， $\tilde{p}_{\theta,c}(\mathbf{x})$ 则是待学习的数据密度形式；优化过程中后者未必已经归一化。最大化二分类对数似然

$$\begin{aligned} J_{\text{NCE}} &= \sum_{j=1}^n \log a_{\theta,c}(\mathbf{x}_j) \\ &\quad + \sum_{l=1}^{\nu n} \log\{1 - a_{\theta,c}(\mathbf{y}_l)\}, \quad \mathbf{y}_l \sim p_N, \end{aligned}$$

³ C. Varin, N. Reid, D. Firth, *An Overview of Composite Likelihood Methods* In *Statistica Sinica*, 2011, vol. 21, pp. 5–42

无需在每一步计算 Z 。在正确设定和可识别等条件下，NCE 可以一致估计密度；这不是有限噪声样本下与 MLE 完全相同的目标。噪声覆盖不足或分类任务过易也会影响学习。这里的 D 只是数据与噪声的来源标签，不是原图中的待预测节点⁴。

对连续、光滑且正的密度，还有另一种消去归一化常数的方法。**分数匹配** (score matching) 匹配的是数据空间中的对数密度梯度 $\mathbf{s}_\theta(\mathbf{x}) = \nabla_{\mathbf{x}} \log p_\theta(\mathbf{x})$ ，不是对参数求导的似然得分。由于 $\log Z(\theta)$ 不依赖 $\mathbf{x}$ ，它在这里消失。若真实密度 p_* 及模型满足可积性条件，且分部积分的边界项为零，则

$$\begin{aligned} J_{\text{SM}}(\theta) &= \frac{1}{2} \mathbb{E}_{p_*} \|\mathbf{s}_\theta - \nabla_{\mathbf{x}} \log p_*\|_2^2 \\ &= \mathbb{E}_{p_*} \left[\frac{1}{2} \|\mathbf{s}_\theta\|_2^2 + \nabla_{\mathbf{x}} \cdot \mathbf{s}_\theta \right] + C. \end{aligned} \quad (24.11)$$

C 与模型参数无关。关键一步是分部积分：

$$-\int \mathbf{s}_\theta^\top \nabla p_* d\mathbf{x} = \int p_* \nabla \cdot \mathbf{s}_\theta d\mathbf{x}.$$

因此未知的真实分数从可优化部分消失，可以用训练样本均值替代期望。这一标准形式不能直接用于离散变量或边界项不消失的受限支持；它优化的是分数之间的差距，而不是直接近似似然梯度⁵。

有限步链则需要单独辨认。**对比散度** (contrastive divergence, CD) 通常从训练样本启动以 p_θ 为平稳分布的 Markov 链，运行 k 步，以终点统计量替代模型期望。若经验分布为 $\hat{p}$ 、转移核为 K_θ ，则其期望更新方向为

$$\mathbf{g}_{\text{CD},k} = \mathbb{E}_{\hat{p}}[\mathbf{T}] - \mathbb{E}_{\hat{p}K_\theta^k}[\mathbf{T}].$$

有限 k 时， $\hat{p}K_\theta^k$ 通常不同于 p_θ ，所以即使无限增加平行链数、消除了 Monte Carlo 波动，偏差仍可能存在。虽然名称来自两个 KL 散度之差，但链终点分布也依赖参数；通常更新省略了这部分导数，一般不能解释为某个固定替代目标的精确梯度。已有二值受限玻尔兹曼机的反例直接说明这一点，特殊转移核下的对应关系不应推广成一般结论⁶。

持久链 (persistent chain) 在下次参数更新时沿用上次的链状态，避免每次都从数据重新启动。它试图在模型缓慢变化时持续跟踪模型分布，但固定的少量转移并不保证链已达到新参数下的平稳状态。充分混合的 MCMC 与有限步持久链使用同一个模型期望公式，区别在于后者依赖跨迭代跟踪的近似；CD 还固定采用数据初始化。它们与伪似然、NCE 和分数匹配的区别，则在于后几种方法明确改变了学习准则。讨论效果时，既要说明计算预算，也要说明所优化或近似的对象⁷。

⁴ M. U. Gutmann, A. Hyvärinen, *Noise-Contrastive Estimation of Unnormalized Statistical Models, with Applications to Natural Image Statistics* In Journal of Machine Learning Research, 2012, vol. 13, no. 11, pp. 307–361

⁵ A. Hyvärinen, *Estimation of Non-Normalized Statistical Models by Score Matching* In Journal of Machine Learning Research, 2005, vol. 6, no. 24, pp. 695–709

⁶ I. Sutskever, T. Tieleman, *On the Convergence Properties of Contrastive Divergence* In Proceedings of the Thirteenth International Conference on Artificial Intelligence and Statistics, 2010, pp. 789–795

⁷ I. Goodfellow, Y. Bengio, A. Courville, *Deep Learning*, MIT Press, 2016

24.2.3 条件无向图

若目标是根据已经给出的测量 $\mathbf{x}$ 预测一组标签 $\mathbf{y}$, 就可以只归一化标签空间。**条件随机场** (conditional random field, CRF) 通过局部特征组织一个条件联合分布, 让多个标签在给定输入以后仍能相互依赖。在线性参数化下写为

$$p_{\theta}(\mathbf{y} | \mathbf{x}) = \frac{\exp\{\boldsymbol{\theta}^{\top} \mathbf{f}(\mathbf{x}, \mathbf{y})\}}{Z_{\theta}(\mathbf{x})}, \quad (24.12)$$

$$Z_{\theta}(\mathbf{x}) = \sum_{\mathbf{y}'} \exp\{\boldsymbol{\theta}^{\top} \mathbf{f}(\mathbf{x}, \mathbf{y}')\}.$$

特征 $\mathbf{f}$ 通常是各团特征的和, 可以依赖整个已知输入; 图主要限制标签之间的相互作用。不同输入有不同的条件配分函数, 不能把所有样本的归一化项合并成一个与输入无关的数。

对完整标签训练集 $\{(\mathbf{x}_j, \mathbf{y}_j)\}_{j=1}^n$, 以 $\lambda \geq 0$ 控制二次正则化, 目标及梯度为

$$J(\boldsymbol{\theta}) = \sum_{j=1}^n \left[\boldsymbol{\theta}^{\top} \mathbf{f}(\mathbf{x}_j, \mathbf{y}_j) - \log Z_{\theta}(\mathbf{x}_j) \right] - \frac{\lambda}{2} \|\boldsymbol{\theta}\|_2^2, \quad (24.13)$$

$$\nabla_{\boldsymbol{\theta}} J = \sum_{j=1}^n \left[\mathbf{f}(\mathbf{x}_j, \mathbf{y}_j) - \mathbb{E}_{p_{\theta}(\mathbf{Y}|\mathbf{x}_j)} \mathbf{f}(\mathbf{x}_j, \mathbf{Y}) \right] - \lambda \boldsymbol{\theta}.$$

推导与无向联合模型相同, 只是每次都固定输入再求和。梯度要求“在这一输入下, 真实标签的特征”与“模型可能预测的所有标签的平均特征”匹配。 $\lambda > 0$ 时, 正则项也可解释为各参数服从方差 λ^{-1} 的零均值高斯先验所产生的 MAP 项。

例如, 只有一个二元标签、一个标量特征 $f(\mathbf{x}, y) = yx$ 时, $p_{\theta}(Y = 1 | \mathbf{x}) = \text{sigmoid}(\theta x)$ 。单条记录 $(x, y) = (2, 1)$ 在 $\theta = 0$ 处贡献梯度 $2 - 2 \times 0.5 = 1$, 推动正类概率上升。多个相互依赖的标签使这种期望计算变复杂: 线性链可以通过前向后向递推计算局部边缘, 一般图则可能需要近似推断。固定特征的线性 CRF 具有凹的条件对数似然, 但无正则化时仍可能因可分离等情形没有有限最优解; 神经特征参与学习时也不再一般地凹。第 27 章将展开具体 CRF 结构及其计算。

24.3 观测完整但含潜变量的参数学习

现在假定按设计应记录的数据字段 $\mathbf{X}$ 全部可见, 但模型还含有从不直接观测的潜变量 $\mathbf{Z}$ 。完整观测不再提供完整模型配置, 局部计数或回归矩必须由潜变量后验的期望替代。本节主要讨论 MLE 与 MAP 点估计: 先写出需要优化的观测数据似然, 再以精确 EM、GEM、近似 E 步和摊销推断说

明推断与参数更新怎样配合。

24.3.1 观测数据似然

没有观测到 $\mathbf{z}_j$ ，并不意味着可以把它设置为零或直接删除其因子。每种相容取值都可能产生当前记录，因此要按模型概率加总：

$$\ell(\theta) = \sum_{j=1}^n \log p_{\theta}(\mathbf{x}_j) = \sum_{j=1}^n \log \int p_{\theta}(\mathbf{x}_j, \mathbf{z}_j) d\mathbf{z}_j. \quad (24.14)$$

离散变量把积分换成求和。这里的**边缘似然** (marginal likelihood) 是消去潜变量之后、仍作为 θ 函数的观测似然；它不同于式 (24.2) 分母中进一步积分参数所得的模型证据。前者用于本章的参数优化，后者常用于模型比较。

对数外面有求和、里面又有积分，模型配置完整时可得的局部计数不再直接可用。在微分与积分可交换、观测密度为正时，

$$\begin{aligned} \nabla_{\theta} \log p_{\theta}(\mathbf{x}_j) &= \frac{\int \nabla_{\theta} p_{\theta}(\mathbf{x}_j, \mathbf{z}_j) d\mathbf{z}_j}{p_{\theta}(\mathbf{x}_j)} \\ &= \mathbb{E}_{p_{\theta}(\mathbf{z}_j|\mathbf{x}_j)}[\nabla_{\theta} \log p_{\theta}(\mathbf{x}_j, \mathbf{z}_j)]. \end{aligned} \quad (24.15)$$

第二个等号使用 $\nabla p = p \nabla \log p$ ，再将联合密度除以观测密度识别为后验。这说明直接梯度优化同样需要当前参数下的后验推断。对离散 CPT，原来的事件指示量要换成“该事件在当前观测下发生的后验概率”。这个概率又依赖正在学习的参数，不能预先算一次就永久当作真实计数。

沿用表 24.1 的过热总数，考虑另一种模型：数据字段只有 H ，故障状态 F 被主动设置为潜变量； A, S 在这次教学计算中不进入模型。为了只研究一个未知量，把过热条件概率固定为另行给定的校准值 $p(H=1|F=1)=0.8$ 和 $p(H=1|F=0)=0.1$ ，仅学习 $\pi = p(F=1)$ 。这里没有本应记录却漏记的 F ，也不是重新使用完整表估计两个条件概率。于是

$$p_{\pi}(H=1) = 0.8\pi + 0.1(1-\pi) = 0.1 + 0.7\pi.$$

20 条记录中 6 条过热、14 条不过热，观测对数似然为

$$\ell(\pi) = 6 \log(0.1 + 0.7\pi) + 14 \log(0.9 - 0.7\pi), \quad 0 \leq \pi \leq 1. \quad (24.16)$$

它在 $p_{\pi}(H=1) = 6/20$ 处最大，故 $\hat{\pi}_{\text{ML}} = 2/7$ 。这个一维例子可以直接解出，适合用来检查 EM；更复杂图中的边缘似然通常不能这样化简。若把两项过热条件概率也设为未知，单一的过热频率便不足以识别三个参数，困难就不只是如何优化了。

24.3.2 精确 EM

式 (24.15) 把未知状态换成后验平均。观测量与未观测随机量合称为**完全数据** (complete data); 本节中它是 $(\mathbf{X}, \mathbf{Z})$, 不表示 $\mathbf{Z}$ 真的被记录下来。若给定完全数据后容易求出最优参数, 我们可以进一步利用这一结构: 在当前参数下算出潜变量的后验统计量, 再把它们固定下来更新参数。**期望最大化算法** (expectation-maximization algorithm, EM) 正是这样交替进行推断与优化; E 步不是把每个潜变量硬选成一个最可能值, M 步也不是对刚才的随机猜测重新计数。

为推导更新为何有效, 对每条记录引入潜变量分布 $q_j(\mathbf{z}_j)$ 。先取它在相应联合密度为正的支撑上为正, 并假设下式期望与熵有限。利用 $\log$ 的凹性和 Jensen 不等式,

$$\begin{aligned} \log p_{\theta}(\mathbf{x}_j) &= \log \mathbb{E}_{q_j} \left[\frac{p_{\theta}(\mathbf{x}_j, \mathbf{Z}_j)}{q_j(\mathbf{Z}_j)} \right] \\ &\geq \mathbb{E}_{q_j} \log p_{\theta}(\mathbf{x}_j, \mathbf{Z}_j) + \mathcal{H}(q_j), \end{aligned} \quad (24.17)$$

其中 $\mathcal{H}(q_j) = -\mathbb{E}_{q_j} \log q_j$, 连续情形为微分熵。每条记录的右侧就是式 (22.1) 中的 $\mathcal{L}(q_j)$; 这里只是显式恢复待学习的模型参数。把各条记录相加, 记下界为 $\mathcal{F}(q, \theta)$ 。更精确的关系是

$$\begin{aligned} \mathcal{F}(q, \theta) &= \sum_j \{ \mathbb{E}_{q_j} \log p_{\theta}(\mathbf{x}_j, \mathbf{Z}_j) + \mathcal{H}(q_j) \}, \\ \ell(\theta) &= \mathcal{F}(q, \theta) + \sum_j \text{KL}(q_j \parallel p_{\theta}(\mathbf{Z}_j \mid \mathbf{x}_j)). \end{aligned} \quad (24.18)$$

第二式直接由后验密度的定义代入 KL 散度得到; 只要 q_j 对后验绝对连续且各项有限, 它也适用于 q_j 仅覆盖部分后验支持的情况。这就是本章使用的**证据下界** (evidence lower bound, ELBO): 它的下界对象是当前参数下的观测对数似然。KL 散度非负, 并且在 q_j 等于真实后验时为零, 因此这个下界可以在当前参数处与似然相等。

固定第 t 次参数 $\theta^{(t)}$, E 步取

$$q_j^{(t)}(\mathbf{z}_j) = p_{\theta^{(t)}}(\mathbf{z}_j \mid \mathbf{x}_j).$$

随后固定这些分布, 定义

$$\begin{aligned} Q(\theta \mid \theta^{(t)}) &= \sum_j \mathbb{E}_{q_j^{(t)}} \log p_{\theta}(\mathbf{x}_j, \mathbf{Z}_j), \\ \theta^{(t+1)} &\in \arg \max_{\theta \in \Theta} Q(\theta \mid \theta^{(t)}). \end{aligned} \quad (24.19)$$

熵在 M 步中不依赖新参数, 所以最大化 Q 等价于最大化固定 $q^{(t)}$ 的下界。这里必须区分积分所用的旧参数与被优化的新参数; 若在 M 步里随意重

算 q , 就不再是这个固定下界的优化。

定理 24.1 EM 的观测似然单调性 设 $\mathbf{x}_1, \dots, \mathbf{x}_n$ 为固定观测, $\mathbf{Z}_j$ 为第 j 条记录的潜变量。对每个 j , 分别在观测空间和潜变量空间上给定 σ 有限基准测度 ν_j 与 μ_j ; 对每个 $\theta \in \Theta$, $p_\theta(\mathbf{x}, \mathbf{z})$ 是相对于共同乘积测度 $\nu_j \otimes \mu_j$ 的联合密度。有限离散情形取计数测度, 此时该密度就是联合概率质量函数。定义观测边缘密度, 并在该边缘正且有限时定义后验密度:

$$\begin{aligned} p_\theta(\mathbf{x}_j) &:= \int p_\theta(\mathbf{x}_j, \mathbf{z}) d\mu_j(\mathbf{z}), \\ r_{j,\theta}(\mathbf{z} | \mathbf{x}_j) &:= \frac{p_\theta(\mathbf{x}_j, \mathbf{z})}{p_\theta(\mathbf{x}_j)}, \\ \ell(\theta) &:= \sum_{j=1}^n \log p_\theta(\mathbf{x}_j). \end{aligned}$$

取 $\theta^{(t)}, \theta^{(t+1)} \in \Theta$, 假设对 $s \in \{t, t+1\}$ 及每个 j 都有 $0 < p_{\theta^{(s)}}(\mathbf{x}_j) < \infty$ 。E 步精确取 $q_j^{(t)}(\mathbf{z}) = r_{j,\theta^{(t)}}(\mathbf{z} | \mathbf{x}_j)$, 并定义

$$Q(\theta | \theta^{(t)}) := \sum_{j=1}^n \int q_j^{(t)}(\mathbf{z}) \log p_\theta(\mathbf{x}_j, \mathbf{z}) d\mu_j(\mathbf{z}).$$

假设对每个 j 及 $s \in \{t, t+1\}$, 都有

$$\int q_j^{(t)}(\mathbf{z}) \log p_{\theta^{(s)}}(\mathbf{x}_j, \mathbf{z}) d\mu_j(\mathbf{z}) \in \mathbb{R},$$

并且

$$\text{KL}\left(q_j^{(t)} \parallel r_{j,\theta^{(t+1)}}(\cdot | \mathbf{x}_j)\right) := \int q_j^{(t)}(\mathbf{z}) \log \frac{q_j^{(t)}(\mathbf{z})}{r_{j,\theta^{(t+1)}}(\mathbf{z} | \mathbf{x}_j)} d\mu_j(\mathbf{z}) < \infty,$$

其中不满足绝对连续时按惯例令 KL 散度为 $+\infty$ 。若新参数满足

$$Q(\theta^{(t+1)} | \theta^{(t)}) \geq Q(\theta^{(t)} | \theta^{(t)}),$$

则 $\ell(\theta^{(t+1)}) \geq \ell(\theta^{(t)})$ 。

证明. 由 $q_j^{(t)} = r_{j,\theta^{(t)}}(\cdot | \mathbf{x}_j)$ 及后验密度的定义, 对 $q_j^{(t)}$ 几乎处处有

$$\log \frac{q_j^{(t)}(\mathbf{z})}{r_{j,\theta^{(t+1)}}(\mathbf{z} | \mathbf{x}_j)} = \log \frac{p_{\theta^{(t)}}(\mathbf{x}_j, \mathbf{z})}{p_{\theta^{(t+1)}}(\mathbf{x}_j, \mathbf{z})} + \log \frac{p_{\theta^{(t+1)}}(\mathbf{x}_j)}{p_{\theta^{(t)}}(\mathbf{x}_j)}.$$

定理中的有限性条件允许对该等式积分并重排有限项。逐个 j 相加得到

$$\begin{aligned}\ell(\boldsymbol{\theta}^{(t+1)}) - \ell(\boldsymbol{\theta}^{(t)}) &= Q(\boldsymbol{\theta}^{(t+1)} | \boldsymbol{\theta}^{(t)}) \\ &\quad - Q(\boldsymbol{\theta}^{(t)} | \boldsymbol{\theta}^{(t)}) \\ &\quad + \sum_{j=1}^n \text{KL}(q_j^{(t)} \| r_{j, \boldsymbol{\theta}^{(t+1)}}(\cdot | \mathbf{x}_j)).\end{aligned}$$

右侧的 Q 函数之差由假设非负，各 KL 散度也非负，因此观测对数似然不下降。 ■

这个证明只依赖下界在旧点精确贴合，以及同一下界在 M 步得到改进。它没有证明找到全局最大值，也没有证明每次严格增加；即使似然值收敛，参数序列的收敛和极限点性质仍需额外条件。EM 的原始论文给出了含未观测量的数据学习框架，而下界视角清楚展示了哪些更新仍保留上述论证⁸。

对离散有向图，E 步实际需要的是各节点家庭的后验边缘，而不必显式列出整个联合后验。沿用章首覆盖全部图节点的 $\mathbf{W} = (\mathbf{X}^\top, \mathbf{Z}^\top)^\top$ ，将式 (24.4) 中的计数替换为

$$\bar{N}_{i,a,k}^{(t)} = \sum_{j=1}^n p_{\boldsymbol{\theta}^{(t)}}(W_i = k, \mathbf{W}_{\text{pa}(i)} = \mathbf{a} | \mathbf{X} = \mathbf{x}_j), \quad (24.20)$$

这里 $\mathbf{x}_j$ 是第 j 条完整观测记录；若节点 i 或其父节点中含有潜变量，条件概率便对这些未观测取值求后验平均。 M 步将每行期望计数归一化，即 $\boldsymbol{\theta}_{i,a,k}^{(t+1)} = \bar{N}_{i,a,k}^{(t)} / \sum_l \bar{N}_{i,a,l}^{(t)}$ ，分母为正时成立。期望计数可以是小数；其含义是当前模型给各节点家庭事件分配的总后验权重。对高斯局部模型，所需的是潜变量的一阶矩、二阶矩和交叉乘积期望；只把潜变量替换成后验均值会丢掉条件方差，通常不是正确的 E 步。

算法 24.1 利用后验充分统计量的 EM

输入： 观测数据、固定联合模型、可行初值 $\boldsymbol{\theta}^{(0)}$ 、容差 $\varepsilon > 0$ 和迭代上限

输出： 参数估计及观测对数似然的迭代记录

```

1: for  $t = 0, 1, \dots$ , 直到达到迭代上限 do
2:   对各记录在  $\boldsymbol{\theta}^{(t)}$  下作后验推断，聚合所需充分统计量
3:   固定这些统计量，最大化  $Q(\boldsymbol{\theta} | \boldsymbol{\theta}^{(t)})$ ，得到  $\boldsymbol{\theta}^{(t+1)}$ 
4:   计算  $\Delta_t = \ell(\boldsymbol{\theta}^{(t+1)}) - \ell(\boldsymbol{\theta}^{(t)})$ 
5:   if  $0 \leq \Delta_t \leq \varepsilon(1 + |\ell(\boldsymbol{\theta}^{(t)})|)$  then
6:     停止迭代并返回当前参数
7:   end if
8: end for
```

算法 24.1 的停止判据要求能够可靠计算观测似然。若 Δ_t 超出数值容差

⁸ A. P. Dempster, N. M. Laird, D. B. Rubin, *Maximum Likelihood from Incomplete Data via the EM Algorithm* In Journal of the Royal Statistical Society: Series B (Methodological), 1977, vol. 39, no. 1, pp. 1–22

地为负，应检查推断、M 步和数值实现；不能把它当成精确 EM 的正常现象。无法精确评估似然时，需要另行报告所监测的近似目标与误差，不能把近似停止条件解释为已经验证精确单调性。

示例 24.2 由过热记录学习故障率 使用式 (24.16) 的 6 条过热、14 条不过热记录，并从 $\pi^{(0)} = 0.1$ 出发。E 步分别计算

$$r_1 = p(F = 1 | H = 1) = \frac{0.1 \times 0.8}{0.1 \times 0.8 + 0.9 \times 0.1} = \frac{8}{17},$$

$$r_0 = p(F = 1 | H = 0) = \frac{0.1 \times 0.2}{0.1 \times 0.2 + 0.9 \times 0.9} = \frac{2}{83}.$$

故障期望计数为 $6r_1 + 14r_0 = 4460/1411 \approx 3.1609$ ，不是 6，也不是把每条记录硬分配后得到的整数。M 步最大化

$$Q(\pi | \pi^{(0)}) = (6r_1 + 14r_0) \log \pi + (20 - 6r_1 - 14r_0) \log(1 - \pi) + C,$$

因而 $\pi^{(1)} = (6r_1 + 14r_0)/20 = 223/1411 \approx 0.158044$ 。用自然对数代回观测似然，有 $\ell(\pi^{(0)}) \approx -13.240355$ 、 $\ell(\pi^{(1)}) \approx -12.657187$ 。再做一轮得到 $\pi^{(2)} \approx 0.208111$ 、 $\ell(\pi^{(2)}) \approx -12.369507$ ；直接求得的最优值为 $\ell(2/7) \approx -12.217286$ 。

图 24.1 显示第一轮几何关系。M 步最大化的是旧后验构造的下界，不是一步直接跳到观测似然的峰值；新参数处下界与似然之间的间隙，会在下一次精确 E 步中被补齐。这个差别解释了为何一个已能直接求解的一维问题，EM 仍可能需要多轮更新。




图 24.1 故障率例子的第一轮 EM。实线是观测对数似然，虚线是固定 $\pi^{(0)} = 0.1$ 后验所得的下界。两者在旧参数处相等；下界在 $\pi^{(1)} \approx 0.158044$ 处最大，而观测似然在 $2/7$ 处最大。图中纵轴为自然对数，曲线可由正文公式直接复算。




图 24.2 同一标量例子的多轮 EM 轨迹。红点依次为 $\pi^{(0)}, \dots, \pi^{(6)}$ ，纵坐标均使用观测对数似然而非各轮不同的下界；蓝色菱形是解析 MLE $2/7$ 。轨迹展示似然逐轮上升并逐渐靠近驻点，但不把这一维构造推广为一般 EM 的全局最优保证。

24.3.3 广义 EM 与近似 E 步

定理 24.1 并没有要求 M 步一定找到 Q 的全局最大值。**广义 EM** (generalized EM, GEM) 保留精确 E 步，只要求 M 步改进同一个 Q。例如，对 Q 做带回溯检查的梯度上升，或依次改进几个参数块，只要总更新不降低 Q，就仍能保证观测似然不下降。任意走一步梯度、未经检查地使用过大步长，并不自动满足 GEM 的条件。

如果后验推断本身难以完成，则可以限制 q 属于某个可计算分布族 $\mathcal{Q}$ 。

变分 EM (variational EM) 在 $\mathcal{F}(q, \theta)$ 上交替改进近似后验和参数：

$$\begin{aligned} q^{(t+1)} &\in \arg \max_{q \in \mathcal{Q}} \mathcal{F}(q, \theta^{(t)}), \\ \theta^{(t+1)} &\in \arg \max_{\theta \in \Theta} \mathcal{F}(q^{(t+1)}, \theta). \end{aligned} \quad (24.21)$$

精确最大化可以放宽为保证同一目标不下降的更新。在固定数据、模型和变分族下，两步都做到这一点，便有

$$\mathcal{F}(q^{(t+1)}, \theta^{(t+1)}) \geq \mathcal{F}(q^{(t)}, \theta^{(t)}).$$

但近似后验一般不能使 KL 间隙为零，旧点的“下界等于似然”不再成立，所以这个结论只保证 ELBO 单调，不保证观测似然单调⁹。

更明确地，记 $K_t = \sum_j \text{KL}(q_j^{(t)} \| p_{\theta^{(t)}}(\mathbf{Z}_j | \mathbf{x}_j))$ ，并简记 $\mathcal{F}_t = \mathcal{F}(q^{(t)}, \theta^{(t)})$ ，则式 (24.18) 给出

$$\ell(\theta^{(t+1)}) - \ell(\theta^{(t)}) = \mathcal{F}_{t+1} - \mathcal{F}_t + K_{t+1} - K_t.$$

即使第一项非负，后验近似间隙的变化仍可能使总和为负。随机梯度或有噪声的下界估计，还可能连逐步 ELBO 单调性都不具备。Monte Carlo E 步

⁹ R. M. Neal, G. E. Hinton, “A View of the EM Algorithm That Justifies Incremental, Sparse, and Other Variants”, in: *Learning in Graphical Models*, ed. by M. I. Jordan, Dordrecht: Kluwer Academic Publishers, 1998, pp. 355–368

用有限样本近似 Q 时, 同样不能直接套用精确 EM 定理; 需要控制采样误差并核查实际改进。

MAP 也可以采用 EM 式更新: E 步仍计算给定当前参数的潜变量后验, M 步改进 $Q(\theta | \theta^{(t)}) + \log p(\theta)$ 。在对应条件下, 单调对象变成 $\ell(\theta) + \log p(\theta)$, 即相差常数的对数后验密度, 而非数据似然本身。把先验引入 M 步不等于保留了参数后验; 这仍是点估计方法。

24.3.4 摊销推断与 Wake-Sleep

变分 EM 若为每条记录分别保存 q_j , 新记录到来时还要重新求解一个局部优化问题。**摊销推断** (amortized inference) 改用共享映射 $q_\phi(\mathbf{z} | \mathbf{x})$, 由识别参数 ϕ 直接把观测映射为近似后验。对固定数据集, 可以联合改进

$$\mathcal{F}(\theta, \phi) = \sum_{j=1}^n \mathbb{E}_{q_\phi(\mathbf{z} | \mathbf{x}_j)} [\log p_\theta(\mathbf{x}_j, \mathbf{Z}) - \log q_\phi(\mathbf{Z} | \mathbf{x}_j)].$$

共享映射减少了逐样本优化与存储, 却需要分清三种不同的差距。若局部变分族 $\mathcal{Q}$ 不包含真实后验, 即使每条记录都求得族内最优 q_j^* , 仍有由变分族限制带来的近似误差。再用共享映射 $q_\phi(\mathbf{z} | \mathbf{x})$ 代替这些逐样本最优解时, 所选映射族的最佳结果与各 q_j^* 之间的目标值差距才是**摊销误差** (amortization error), 有限网络容量是其来源之一。实际训练若尚未达到该映射族内的最优 ϕ , 产生的是优化误差, 不能再归入摊销误差。具体的梯度估计与重参数化方法见第 22.2.3 节。

Wake-Sleep 算法 由 Hinton 等在 1995 年为随机 Helmholtz 机提出。它同时维护自上而下的**生成模型** (generative model) $p_\theta(\mathbf{x}, \mathbf{z})$ 与自下而上的**识别模型** (recognition model) $q_\phi(\mathbf{z} | \mathbf{x})$, 但两组参数不在同一个阶段更新。Wake 阶段从训练数据取得 $\mathbf{x}$, 再由识别模型抽取 $\mathbf{z}$, 固定 ϕ 并更新生成参数 θ , 使这些“数据-解释”对在生成模型下更可能; Sleep 阶段固定 θ , 从生成模型自上而下抽取 $(\mathbf{x}, \mathbf{z})$, 再更新 ϕ , 使识别模型能够从生成出的 $\mathbf{x}$ 恢复对应的 $\mathbf{z}$ ¹⁰。

这两个方向可以写成不同的总体目标。Wake 阶段关于生成参数最大化

$$J_{\text{wake}}(\theta; \phi) = \frac{1}{n} \sum_{j=1}^n \mathbb{E}_{q_\phi(\mathbf{z} | \mathbf{x}_j)} [\log p_\theta(\mathbf{x}_j, \mathbf{Z})], \quad (24.22)$$

它是固定识别模型后 ELBO 中依赖 θ 的部分, 近似后验的间隙方向为 $\text{KL}(q_\phi(\mathbf{Z} | \mathbf{x}) \| p_\theta(\mathbf{Z} | \mathbf{x}))$ 。经典算法用 q_ϕ 的样本形成局部随机更新, 并不在 Wake 阶段沿识别参数求这个 ELBO 的梯度。

¹⁰ G. E. Hinton, P. Dayan, B. J. Frey, R. M. Neal, *The Wake-Sleep Algorithm for Unsupervised Neural Networks* In Science, 1995, vol. 268, no. 5214, pp. 1158–1161

Sleep 阶段关于识别参数最大化

$$\begin{aligned} J_{\text{sleep}}(\phi; \theta) &= \mathbb{E}_{p_{\theta}(\mathbf{X}, \mathbf{Z})} [\log q_{\phi}(\mathbf{Z} | \mathbf{X})] \\ &= -\mathbb{E}_{p_{\theta}(\mathbf{X})} \text{KL}(p_{\theta}(\mathbf{Z} | \mathbf{X}) \| q_{\phi}(\mathbf{Z} | \mathbf{X})) + C(\theta), \end{aligned} \quad (24.23)$$

其中 $C(\theta)$ 与 ϕ 无关。这里的 KL 方向与 Wake 阶段 ELBO 中的方向相反，而且外层输入来自当前生成模型，不是经验数据分布。生成模型尚未覆盖真实数据的重要区域时，Sleep 阶段也不会在这些区域训练识别模型。

因此，Wake-Sleep 不是精确 EM 的另一种实现。它用摊销识别模型近似后验，Sleep 阶段又优化不同方向、不同输入分布下的识别目标；随机更新还会带来抽样与优化误差。算法可以改进各阶段实际使用的目标，却没有“每轮观测数据似然必不下降”的精确 EM 保证，也不能把 Sleep 目标的改善解释为真实数据 ELBO 必然改善。

24.4 观测缺失下的参数学习

观测缺失意味着按设计应记录的数据字段没有全部取得。缺失值与潜变量都形成未观测量，所以第 24.3 节的边缘化和近似推断工具可以复用；但在复用之前，必须先判断记录过程是否携带了关于缺失值的额外信息。本节只建立这种映射和适用条件，不重复 EM 推导。

24.4.1 缺失变量与缺失机制

以 $\mathbf{Y}$ 表示本应完整记录的数据向量， $R_i = 1$ 表示 Y_i 已观测， $R_i = 0$ 表示缺失。对一种固定模式 $\mathbf{r}$ ，把 $\mathbf{y}$ 拆为 $\mathbf{y}_{\text{obs}}$ 与 $\mathbf{y}_{\text{mis}}$ ，拆分位置由 $\mathbf{r}$ 决定。数据模型为 $p_{\theta}(\mathbf{y})$ ，**缺失机制** (missingness mechanism) 为 $p_{\psi}(\mathbf{r} | \mathbf{y})$ ，其中 ψ 控制记录过程。机制描述的是“哪些值容易漏记”，不能由某次填补出的数值来定义。

定义 24.3 缺失机制 以下条件均针对机制模型中每个允许的 ψ 。**完全随机缺失** (missing completely at random, MCAR) 要求 $p_{\psi}(\mathbf{r} | \mathbf{y}) = p_{\psi}(\mathbf{r})$ ，即缺失模式不依赖数据值。**随机缺失** (missing at random, MAR) 要求对每种模式 $\mathbf{r}$ 及所有相容的数据值，

$$p_{\psi}(\mathbf{r} | \mathbf{y}_{\text{obs}}, \mathbf{y}_{\text{mis}}) = p_{\psi}(\mathbf{r} | \mathbf{y}_{\text{obs}}).$$

固定已经观测的部分后，改变缺失值不会改变该模式的概率。违反此条件称为**非随机缺失** (missing not at random, MNAR)。

MCAR 是 MAR 的特例，并非三个互不相交的类；日常并列使用三个名称时，中间一类通常特指 MAR 但非 MCAR。MAR 中的“随机”也不表示

所有记录有相同缺失概率。譬如， F, A, S 均已记录，只有过热指标 H 可能漏记：若独立的日志故障决定是否漏记，这是 MCAR；若报警设备更容易接受温度检查，缺失只依赖已记录的 A ，这是 MAR；若在相同 F, A, S 下，过热本身仍改变温度报告丢失的概率，则是 MNAR。图 24.3 表示了这些依赖差别。




图 24.3 固定已观测的 F, S 后，温度记录指示量 R_H 的三种示意机制。三栏顶部直接给出 R_H 的父集，底部分别配独立日志故障、报警后安排检查、过热改变漏报概率的日常例子。 A 总是观测， H 在 $R_H = 0$ 时不可见；右图需有实际的剩余依赖才属于 MNAR，单凭箭头存在不能排除参数抵消。

24.4.2 可忽略性

是否可以不建模 $\mathbf{R}$ ，要由实际观测的似然判断。对一条记录，令 $\mathbf{y} = (\mathbf{y}_{\text{obs}}, \mathbf{y}_{\text{mis}})$ ，在 MAR 下有

$$\begin{aligned} L(\theta, \psi) &= \int p_{\theta}(\mathbf{y}) p_{\psi}(\mathbf{r} | \mathbf{y}) d\mathbf{y}_{\text{mis}} \\ &= p_{\psi}(\mathbf{r} | \mathbf{y}_{\text{obs}}) p_{\theta}(\mathbf{y}_{\text{obs}}). \end{aligned} \quad (24.24)$$

第二行把不依赖积分变量的机制因子提出。若 θ 与 ψ 的参数空间可分离为 $\Theta \times \Psi$ ，即允许任一合法数据参数与任一合法机制参数组合，那么关于 θ 的似然比较不需要机制因子。仅给两组参数起不同名字并不够；若它们受到共同约束，机制仍可能限制 θ 。这里的**可忽略性**（ignorability）只表示估计数据参数时可以省略缺失模型，不表示缺失没有损失信息。

基于分布的参数估计还需要适当的先验分离。若 $p(\theta, \psi) = p(\theta)p(\psi)$ 且相关积分存在，则在 MAR 下积分掉 ψ 只留下与 θ 无关的因子，故 $p(\theta | \mathbf{y}_{\text{obs}}, \mathbf{r}) \propto p_{\theta}(\mathbf{y}_{\text{obs}})p(\theta)$ 。若先验把二者关联起来，积分 $\int p_{\psi}(\mathbf{r} | \mathbf{y}_{\text{obs}})p(\psi | \theta) d\psi$ 一般仍依赖 θ ，不能删除。上述是常用的充分条件，不是每个特定参数问题的必要条件，也不直接等于任意删行或填补程序的有效性保证¹¹。

¹¹ D. B. Rubin, *Inference and Missing Data* In *Biometrika*, 1976, vol. 63, no. 3, pp. 581–592

24.4.3 可忽略缺失下复用未观测变量方法

在可忽略条件下，可以把每条记录实际可见的部分作为 $\mathbf{x}_j = \mathbf{y}_{j,\text{obs}}$ ，把缺失部分作为 $\mathbf{z}_j = \mathbf{y}_{j,\text{mis}}$ ，直接复用第 24.3 节的观测似然、梯度恒等式、精确 EM 或近似 E 步。模型若还含主动设置的潜变量 $\mathbf{h}_j$ ，就把未观测量合并为 $\mathbf{z}_j = (\mathbf{y}_{j,\text{mis}}, \mathbf{h}_j)$ ；不同记录可以有不同缺失模式，但每次推断都必须固定该记录实际观测到的分量。

这种映射只复用工具，不把缺失值重新定义为潜变量。删去不完整记录会改变实际使用的数据分布，单次均值填补会忽略条件方差，把缺失值硬填为后验众数也不是 EM 的 E 步。对离散模型，应计算相关家庭事件的后验期望计数；对高斯模型，还需二阶矩与交叉矩。若采用摊销推断，识别模型还必须接收缺失掩码或等价的观测模式信息，不能把填充值本身误当成真实观测。

24.4.4 不可忽略缺失与可识别性

MNAR 时，记录过程在给定已观测值后仍依赖缺失值，式 (24.24) 通常不能分解。此时应为

$$p_{\theta, \psi}(\mathbf{y}, \mathbf{r}) = p_{\theta}(\mathbf{y})p_{\psi}(\mathbf{r} | \mathbf{y})$$

建立联合模型，把 $\mathbf{R}$ 作为已观测变量，并对 $\mathbf{Y}_{\text{mis}}$ 以及原有潜变量共同边缘化。给定这个联合模型后，仍可使用第 24.3 节的优化与推断工具；改变的是被拟合的联合分布和待估参数，而不是另造一套 EM 公式。

联合建模并不自动解决可识别性。不同的数据分布与缺失机制可能诱导同一个 $p(\mathbf{y}_{\text{obs}}, \mathbf{r})$ ，仅凭现有记录便无法区分它们。对未观测值怎样改变缺失概率的假设，需要由随访数据、外部测量、有效工具变量、受控采集设计或明确的参数约束提供额外信息；缺少这些信息时，应报告敏感性分析，而不能把某个 MNAR 模型的点估计当作由数据唯一确定的答案。EM 只解决给定模型后的计算，不会使不可忽略机制变得可忽略，也不会创造不存在的识别信息。

24.5 基于分布估计的参数学习

本节所说**分布估计**，专指估计并保留参数后验 $p(\theta | \mathcal{D})$ ，而不是计算固定参数下模型变量的边缘或后验分布。它与前面三种数据可见性设定交叉：无未观测变量且满足共轭条件时可能解析更新；含潜变量或缺失值时通常要联合近似参数与未观测变量；得到参数后验后，再通过后验预测把参数不确定性传给新数据。

24.5.1 不含未观测变量的共轭后验

不含未观测变量时，局部统计量不仅能用来找最优点，也能更新参数分布。

共轭先验 (conjugate prior) 是与似然相乘后仍留在同一分布族中的先验，因此可以用有限组超参数记录整个后验，而不必每次做高维积分。

对一个独立参数块 η ，假设其似然中与参数有关的部分具有形式

$$p(\mathcal{D}_b | \eta) \propto \exp\{\eta^\top \mathbf{S}_b - n_b a(\eta)\},$$

其中 $\mathbf{S}_b$ 是聚合充分统计量， n_b 是该块的观测次数， a 是对应对数归一化函数。若采用相对于指定参数测度、可归一化的先验 $p(\eta | \chi, \nu) \propto \exp\{\eta^\top \chi - \nu a(\eta)\}$ ，则

$$p(\eta | \mathcal{D}_b) \propto \exp\{\eta^\top (\chi + \mathbf{S}_b) - (\nu + n_b) a(\eta)\}. \quad (24.25)$$

指数相加给出 $\chi \leftarrow \chi + \mathbf{S}_b$ 与 $\nu \leftarrow \nu + n_b$ 。这一写法适用于拥有共同归一化函数的参数块，例如离散 CPT 的一行；一般条件指数族的归一化函数可能依赖每条记录的父节点值，不能不看设计条件就把它们都写成 $n_b a(\eta)$ 。

在所有节点均已观测、没有参数共享且先验也按节点和 CPT 行独立分解时，似然的分解使后验同样局部分解：

$$p(\theta | \mathcal{D}) = \prod_{i,a} \text{Dirichlet}(\theta_{i,a}; \alpha_{i,a} + \mathbf{N}_{i,a}). \quad (24.26)$$

数据沿图结构的作用在这里很具体：每条记录只给各节点家庭的相应单元格增加计数。父配置从未出现时，该行后验仍等于先验，并不是一行由数据支持的精确概率。对完整的线性高斯局部回归，适当的正态与逆 Gamma 联合先验也可以利用设计矩阵的交叉乘积解析更新，原理同样是聚合局部充分统计量¹²。

狄利克雷后验保留了整行概率的不确定性，而不只给出式 (24.6) 的众数。记 $\alpha_{i,a,0} = \sum_k \alpha_{i,a,k}$ ，则

$$\mathbb{E}[\theta_{i,a,k} | \mathcal{D}] = \frac{N_{i,a,k} + \alpha_{i,a,k}}{N_{i,a} + \alpha_{i,a,0}}. \quad (24.27)$$

这个后验均值只需正超参数便定义良好，但它是把参数后验再压缩为一个点，不能代替分布本身。均匀狄利克雷先验下，式 (24.6) 的内部 MAP 与 MLE 相同，常见的加一平滑则来自本式的后验均值。

后验是否局部分解取决于似然和先验共同的结构。共享超参数会将原来独立的块联系起来，缺失数据的求和也通常打破式 (24.26)。因此，把 EM 某一轮的期望计数直接当作真实计数，再宣称获得了精确狄利克雷参数后验，是不正确的。EM 固定的是一个参数点，并没有积分该点周围的

¹² K. P. Murphy, *Machine Learning: A Probabilistic Perspective*, MIT Press, 2012

参数不确定性；完整的贝叶斯处理应针对 $p(\theta, \mathbf{z}_{1:n} | \mathcal{D})$ 推断。

设备例子也能展示后验保留了多少信息。表 24.1 给出 5 次故障和 15 次正常，结合 $\text{Beta}(2, 2)$ 先验得到 $\pi | \mathcal{D} \sim \text{Beta}(7, 17)$ 。同一份数据的 MLE、MAP 与后验均值分别为 1/4、3/11 和 7/24；前两者是不同目标的最优点，第三个数只是后验的一项摘要。该后验的方差为

$$\text{Var}(\pi | \mathcal{D}) = \frac{7 \times 17}{24^2 \times 25} = \frac{119}{14400} \approx 0.008264.$$

这份后验仍有明显宽度，不能把 7/24 解释为已知的真实故障率。新增完整记录后，相应成功或失败计数继续累加即可；先验超参数是建模选择，不应伪装成实测样本。

24.5.2 含未观测变量的近似后验

一旦含有潜变量或缺失值，参数后验通常要与未观测变量联合推断；非共轭局部模型和复杂参数共享还会进一步破坏解析形式。此时可以沿用第 22 章和第 23 章的方法，但必须把推断对象由“固定参数下的状态”扩展为“参数与状态”。以下用 $\mathbf{z}_{1:n}$ 统称各条记录中的潜变量和实际缺失字段。对 MNAR， $\mathcal{D}$ 还包含已观测的缺失指示，缺失机制参数 ψ 也属于联合后验；为显式保留这一情形，下面的公式写出 ψ ，不含缺失机制或机制可忽略时则删去所有 ψ 项。

变分方法选取 $q_\phi(\theta, \psi, \mathbf{z}_{1:n})$ ，优化

$$\begin{aligned} \mathcal{L}(\phi) &= \mathbb{E}_{q_\phi}[\log p(\mathcal{D}, \mathbf{z}_{1:n}, \theta, \psi) - \log q_\phi(\theta, \psi, \mathbf{z}_{1:n})], \\ \log p(\mathcal{D}) &= \mathcal{L}(\phi) + \text{KL}(q_\phi \| p(\theta, \psi, \mathbf{z}_{1:n} | \mathcal{D})). \end{aligned} \quad (24.28)$$

这里数据参数 θ 与机制参数 ψ 的先验都已进入联合分布，两者也都在证据中被积分； $\log p(\mathcal{D})$ 在模型和超参数固定时是常数。不含 ψ 时，公式退化为只对数据参数与状态推断。这个目标与变分 EM 中随 θ 变化的观测对数似然下界不是同一个优化问题。常用因子化假设可以降低计算量，却可能遗漏参数间相关性或后验的多个峰；优化下界成功不等于近似族已经足够表达真实后验。

在共轭的变分更新中，期望计数确实可能作为超参数出现，但那属于特定变分族下的坐标更新。相应局部状态更新通常使用 $\exp\{\mathbb{E}[\log \theta_{i,a,k}]\}$ ，而不是把后验均值代入 θ ；一般有 $\mathbb{E}[\log \theta] \neq \log \mathbb{E}[\theta]$ 。这一差别也说明，EM、贝叶斯变分推断与简单的平滑计数不能只凭公式外观互相替代。

MCMC 则构造以参数后验或参数与潜变量联合后验为平稳分布的链，用其样本近似积分。若只关心普通可计算似然，后验中与参数无关的证据常数会在 Metropolis–Hastings 比率中约掉；无向模型的 $Z(\theta)$ 却依赖候选参数，通常不会消失。这类模型可能仍需额外的内层推断或专门的采样构

造。链的混合、多峰之间的移动和有效样本量都需要诊断，不能把“使用 MCMC”当作有限运行已得到精确后验的保证。

若后验在一个内部峰附近集中，还可以用**拉普拉斯近似**(Laplace approximation)，即用峰值附近的二次曲率构造高斯分布。记 $g(\theta) = \log p(\theta | \mathcal{D})$ ，在局部 MAP 点 $\hat{\theta}$ 作二阶展开；若 $\mathbf{H} = -\nabla^2 g(\hat{\theta})$ 正定，则

$$p(\theta | \mathcal{D}) \approx \mathcal{N}(\theta; \hat{\theta}, \mathbf{H}^{-1}).$$

边界峰、明显偏斜、多峰或不可识别方向会破坏这一局部高斯描述。对有约束的参数，宜先选择适当坐标，并将密度变换的 Jacobian 纳入目标；否则曲率和 MAP 的含义都会改变。三类方法都应通过任务相关的后验量或预测量比较，而不只比较优化器是否停止。

24.5.3 后验预测

得到参数后验后，新设备的状态仍具有随机性，而故障率本身也不完全确定。**后验预测**(posterior predictive) 将这两种不确定性合并：在每个可能参数下计算新观测的分布，再按参数后验加权，

$$p(\mathbf{x}_* | \mathcal{D}) = \int p_{\theta}(\mathbf{x}_*) p(\theta | \mathcal{D}) d\theta. \quad (24.29)$$

若预测还涉及新潜变量，应在内层同时消去它们。**插件预测**(plug-in prediction) 则把某个点估计 $\hat{\theta}$ 代入 $p_{\theta}(\mathbf{x}_*)$ ，计算较简单，但忽略了参数分布的宽度。

对单台设备的 Bernoulli 故障变量，后验预测恰好等于代入后验均值的结果： $p(F_* = 1 | \mathcal{D}) = \mathbb{E}[\pi | \mathcal{D}] = 7/24$ 。这只是概率对 π 线性的特例，不说明两种方法一般相同。考虑两台在给定 π 后独立的新设备，则

$$\begin{aligned} p(F_{*,1} = 1, F_{*,2} = 1 | \mathcal{D}) &= \mathbb{E}[\pi^2 | \mathcal{D}] = \frac{7 \times 8}{24 \times 25} = \frac{7}{75}, \\ p_{\text{plug}}(F_{*,1} = 1, F_{*,2} = 1) &= (7/24)^2 = \frac{49}{576}. \end{aligned}$$

两者约为 0.09333 和 0.08507，相差 $\text{Var}(\pi | \mathcal{D})$ 。积分共同参数后，两台设备不再后验预测独立：它们都受到同一故障率未知性的影响。对未来 m 台设备的故障数，完整预测是 Beta-二项分布，而非直接代入平均故障率的二项分布。

条件预测还要说明新输入怎样被处理。纯条件模型把 $\mathbf{x}_*$ 视为给定设计，使用 $\int p_{\theta}(\mathbf{y}_* | \mathbf{x}_*) p(\theta | \mathcal{D}) d\theta$ 。若训练的是联合生成模型，新输入本身也能提供参数信息，则严格的条件后验预测为

$$p(\mathbf{y}_* | \mathbf{x}_*, \mathcal{D}) = \frac{\int p_{\theta}(\mathbf{x}_*, \mathbf{y}_*) p(\theta | \mathcal{D}) d\theta}{\int p_{\theta}(\mathbf{x}_*) p(\theta | \mathcal{D}) d\theta}.$$

等价地，它用 $p(\theta | \mathcal{D}, \mathbf{x}_*)$ 加权条件分布。只有在输入不更新相关参数等条件下，才能直接改用训练后的参数后验作权重。预测对象不同，所需的积分顺序与权重也可能不同。

24.6 学习算法分析

24.6.1 学习与推断的耦合

前面各节的差别现在可以落实为学习时缺少哪一种统计量。观测完整且不含潜变量的有向图已经给出局部事件，独立参数块只需聚合计数或回归矩；联合无向图虽然观测完整，仍需计算全局归一化带来的模型期望；条件无向图需要对每个输入计算输出条件分布的期望；含潜变量或缺失值时，还要计算每条记录条件下的后验期望。若联合无向图同时含有潜变量，两类推断任务会同时存在。

例如，对充分统计量为 $\mathbf{T}(\mathbf{x}, \mathbf{z})$ 的无向指数族潜变量模型，平均观测似然梯度为

$$\begin{aligned} \frac{1}{n} \nabla_{\theta} \ell &= \frac{1}{n} \sum_{j=1}^n \mathbb{E}_{p_{\theta}(\mathbf{Z}|\mathbf{x}_j)}[\mathbf{T}(\mathbf{x}_j, \mathbf{Z})] \\ &\quad - \mathbb{E}_{p_{\theta}(\mathbf{X}, \mathbf{Z})}[\mathbf{T}(\mathbf{X}, \mathbf{Z})]. \end{aligned} \quad (24.30)$$

第一项问的是“这条观测记录可能来自哪些状态”，第二项问的是“模型不附加证据时会产生哪些状态”。二者不能使用同一组条件样本混为一谈。E 步即使容易，M 步若含难算的配分函数，也未必容易。

推断复杂度取决于图结构，而不只取决于参数个数。离散完整有向图可以一次扫描累加家庭计数，但表格存储量约为 $\sum_i r_i \prod_{v \in \text{pa}(i)} r_v$ ，高入度节点仍可能很贵。对最大状态数为 r 、诱导宽度为 w 的离散精确消元，主要因子运算规模通常含 r^{w+1} ；潜变量学习还要针对不同证据重复或批量复用这些运算。图固定时可以复用消元结构与消息调度，但参数更新后消息数值一般需要重算。相关算法见第 20 章和第 21 章。

24.6.2 优化与可扩展性

当样本数很大时，每次遍历全部记录的代价可能超过单次推断。**随机梯度** (stochastic gradient) 从小批量记录估计全数据梯度。若优化平均对数似然，大小为 b 的均匀小批量 $\mathcal{B}$ 给出 $b^{-1} \sum_{j \in \mathcal{B}} \nabla \log p_{\theta}(\mathbf{x}_j)$ ；若优化总和目标，则相应乘以 n 。先验项不随样本数重复累加，因而从总和切到均值目标时，正则项也必须同步除以 n ，否则实际上改变了先验相对于数据的强度。

小批量能减少经验项计算，却不会自动解决模型期望或后验推断的偏

差。可把实际更新使用的梯度写成

$$\hat{\mathbf{g}}^{(t)} = \nabla J(\boldsymbol{\theta}^{(t)}) + \mathbf{b}_{\text{inf}}^{(t)} + \boldsymbol{\xi}^{(t)},$$

其中 $\mathbf{b}_{\text{inf}}^{(t)}$ 表示近似推断带来的系统偏差, $\boldsymbol{\xi}^{(t)}$ 表示中心化后的抽样波动。增加小批量大小主要降低波动, 不能一般地消去固定步数链或受限变分族的偏差。偏差还可能随着参数改变, 因此即使训练曲线平滑, 也未必在逼近原来的似然驻点。

参数共享可以显著减少需要估计的自由度, 并让罕见局部配置借助其他位置的数据。但共享后, 式 (24.3) 虽仍是局部项之和, 同一参数的梯度要从所有出现位置累加。关系模板在一条大图上重复出现, 也不使这些位置自动成为独立样本; 应区分独立设备、独立序列和同一图内部的相关实例。

自动微分 (automatic differentiation) 按照计算图的链式法则求导, 能够处理共享参数和复杂局部网络, 却不会替作者选择正确的统计目标。若反向传播穿过固定次数的消息更新, 得到的是该有限计算过程的导数, 不一定是精确似然的导数。EM 的 M 步则应固定 E 步分布, 对 Q 中的新参数求导; 若无意中让梯度穿过旧后验的构造, 就改变了更新的含义。自动微分减少代数实现错误, 不能补足不准确的归一化或后验期望。

非凸点估计还依赖初始化。不同初值可能把 EM、变分学习或一般梯度法送入不同的吸引区域, 多次初始化可以比较实际目标值和预测表现, 却不能保证已经发现全局最优。潜变量后验越不确定, 参数与期望统计量之间的相互调整还可能越缓慢; 只看参数变化小, 可能把缓慢移动误判为求解充分。

优化目标本身也可能没有有限最大值。高斯混合模型中, 若一个 m 维分量保持固定正权重, 把均值移到某个样本 $\mathbf{x}_j$ 上, 并令协方差为 $\varepsilon^2 \mathbf{I}$, 该点密度正比于 ε^{-m} 。只要其他分量仍给其余样本正密度, 令 $\varepsilon \rightarrow 0$ 就可使总似然无界。这种**退化解** (degenerate solution) 来自目标与可行域的边界, 不是多运行几轮或更换优化器就能消除。对协方差加下界或采用适当先验可以排除相应路径, 但这会改变原来的无约束 MLE 问题。

评价一个学习流程的误差时, 至少要分清三个来源。**统计误差** (statistical error) 来自有限数据, 即使精确求出样本目标的最优解, 也未必接近总体最优参数; **推断误差** (inference error) 来自近似边缘、期望或积分; **优化误差** (optimization error) 则是相对于所选目标尚未充分求解的差距。模型族不包含真实分布还会产生模型设定偏差, 这不能归入优化失败。三类误差未必在参数空间中简单相加, 但这个区分可以指导投入: 更多数据针对统计不确定性, 更准确的内层推断针对近似偏差, 更多优化步数只针对当前目标的求解不足。

24.6.3 学习结果的评价

不可识别性 (non-identifiability) 应在解释参数结果之前检查：若不同参数对应同一个观测分布，数据即使无限多也不能从这些参数中唯一选择一个。交换混合分量的编号并同时交换其权重与局部参数，观测分布不变，这称为**标签交换** (label switching)；因子模型的某些旋转、无向势函数的常数重分配以及 MNAR 模型中数据分布与缺失机制的抵消也会产生不唯一性。约束可以选定一个代表，外部信息可能恢复识别，但增加优化步数不能区分本来观测等价的参数。评价时应优先报告可识别的预测量或与重标记无关的结构，而不是把任意一个参数代表解释为唯一真实机制。

训练似然提高，只说明模型给参与拟合的整批记录分配了更高的概率或密度；条件模型则是在给定输入下提高训练输出的条件似然。若监测的是 MAP、ELBO 或替代准则，该目标改善并不保证数据似然提高。要判断概率模型能否预测新记录，应使用未参与训练和调参的独立测试集；记录具有分组或时间依赖时，划分也应避免同一设备或未来信息泄漏到训练侧。测试平均预测对数似然可以写为

$$\frac{1}{n_{\text{test}}} \sum_{j=1}^{n_{\text{test}}} \log p_{\text{pred}}(\mathbf{x}_j^{\text{test}}).$$

条件模型应改用对应的条件预测概率，缺失数据应使用实际观测部分的概率及所声明的缺失机制。联合分数与条件分数考察的对象不同，不能不加说明地横向比较；连续密度的数值还依赖坐标和单位。

若评估时只能计算 ELBO，它报告的是预测对数似然的下界，不是同一个量的精确值。不同模型或不同近似族的下界间隙可能不同，排名也可能受到影响。无向模型若仍未估计 Z ，未归一化能量不能当作对数概率；伪似然或 CD 训练指标也不能直接代替归一化的测试似然。报告应说明归一化、积分或采样近似所用的方法与误差来源。

对数似然衡量整份概率分配，还可以单独检查概率是否与实际频率吻合。**概率校准** (probability calibration) 要求预测某事件概率约为 u 的记录中，该事件发生比例也约为 u 。对故障预测，可在独立记录上按预测概率分箱，比较每箱平均概率与故障频率，并同时报告箱内样本量或不确定性。稀疏箱中的偏差不宜直接解释为系统性失准；全部预测一个总体故障率也可能校准，却无法区分高风险与低风险设备。因而校准与区分能力、预测对数似然应结合考察。

参数后验还支持更有针对性的模型检查。**后验预测检查** (posterior predictive check) 从后验预测中生成与原数据设计相同的重复数据，再比较具有实际意义的统计量。例如，设备模型可以比较总报警率、各故障组的过热率，以及给定 H, S 后报警与故障之间是否仍有模型没有解释的关联。若研究对象包含缺失过程，复制数据时也应模拟相应记录机制，或明确固

定了什么观测设计。观测统计量长期落在预测分布的边缘，提示模型结构、局部分布或先验可能不适合当前数据。

后验预测检查是诊断模型与数据的不相容之处，不能把同一批数据参与拟合后的吻合程度当作独立泛化证据，也不能把没有发现问题当作模型已经正确。积分参数得到的模型证据、比较两个证据之比的 Bayes 因子，以及 BIC，主要服务于模型或结构比较，且需要考虑先验与正则条件。第 25.2.2 节将给出它们的定义，并说明这种比较与参数拟合、预测评价的区别。

24.7 本章小结

参数学习由数据可见性与参数估计方式两条轴共同决定。前者区分无潜变量的完整观测、含潜变量的完整观测和字段缺失，决定能否直接取得统计量、是否需要边缘化或建模缺失机制；后者区分 MLE、MAP 点估计与保留参数后验的分布估计。两轴可以组合，潜变量、缺失值、非共轭性和全局归一化都可能使两类估计依赖近似推断。

算法保证取决于目标。精确 EM 在精确 E 步、充分 M 步下保证观测似然不下降；广义 EM 保留精确 E 步，M 步只须改善同一 Q 函数。变分 EM 仅当两步都改善同一 ELBO 时，才保证该下界不下降；有限样本 Monte Carlo E 步没有统一的逐轮 ELBO 或观测似然单调保证。Wake-Sleep 优化不同方向的目标，不保证观测似然或真实数据 ELBO 逐轮改善。评价还须区分三类误差，检查初始化、退化边界与不可识别性。

结构学习

已有的设备模型把故障、过热和报警连接成一张图，然后在这张图上估计参数、回答查询。如果手中只有运行记录，没有预先给定的连线，能否从数据中找出图？即使找到了稳定的连线，能否进一步断言箭头就是故障传播的方向？这两个问题看似相近，所需的信息却不同：数据可以支持某种依赖表示，而因果方向还取决于数据怎样产生，以及允许哪些替代解释。

第 17 章和第 18 章说明了给定图如何约束分布，第 24 章则固定图来估计参数。本章把图也作为未知量。理解这一变化，需要把三个环节分开：条件独立检验提供局部证据，结构评分比较整个候选模型，搜索算法决定到哪里寻找候选。图的表示方式限制可搜索的对象，缺失和潜变量改变可利用的证据，因果假设决定所得结构能解释到哪一步。

25.1 结构学习的定义

设节点集合为 $V = \{1, \dots, d\}$ ，随机向量为 $\mathbf{X} = (X_1, \dots, X_d)^\top$ ，完整观测数据为 $\mathcal{D} = \{\mathbf{x}_r : r = 1, \dots, n\}$ 。本章先假定这些样本独立同分布，缺失数据和多干预环境在相应小节另行说明。给定候选图族 $\mathcal{G}$ 及每张图对应的分布族 $\mathcal{M}(\mathcal{G})$ ，**结构学习**（structure learning）就是利用数据和领域知识，选择或评价哪些图适合表示变量之间的依赖。候选图族不仅规定边的类型，也可以限定最大父集、禁止某些边，或者只允许树。

结构学习的输出不一定是一张完全定向的图。为了预测，可以选一个拟合与复杂度折中的有向图；为了表达不确定性，可以保留图上的后验分布；高斯模型可以输出稀疏精度矩阵；若数据只能区分一组图，就应输出这组图共同信息。不同输出不是同一结果的绘图风格，而是对“哪些结论已被确定”的不同承诺。

对有向图，尤其需要理解这种承诺的限度。**Markov 等价类**（Markov equivalence class, MEC）由具有相同 d-分离关系的有向图组成。两张有向图属于同一等价类，当且仅当它们有相同的**骨架**（skeleton），即忽略方向后的邻接关系，以及相同的**无屏蔽碰撞结构**（unshielded collider，又称 v-structure），即 $i \rightarrow k \leftarrow j$ 且 i, j 不相邻。这里比较的是图蕴含的全部条

件独立关系，不是某组参数碰巧产生的独立性。完整的等价性刻画可参见图模型教材¹。

在不附加函数形式限制的有向图模型中，等价图描述同一个分布族。三节点链 $X_1 \rightarrow X_2 \rightarrow X_3$ 、反向链 $X_1 \leftarrow X_2 \leftarrow X_3$ 和分叉 $X_1 \leftarrow X_2 \rightarrow X_3$ 都只要求 $X_1 \perp X_3 \mid X_2$ ；碰撞图 $X_1 \rightarrow X_2 \leftarrow X_3$ 却要求两端边缘独立，因而不在这个等价类中。图 25.1 把“有三张图”与“只能确认什么”放在一起比较。

¹ D. Koller, N. Friedman, *Probabilistic Graphical Models: Principles and Techniques*, MIT Press, 2009




图 25.1 三个无碰撞有向图共享骨架和条件独立关系，以底部的 CPDAG 统一表示。无向边表示方向在类内可变，不表示两个方向同时存在；把两条边同时指向 X_2 会产生新碰撞结构，不是合法补全。

完成的部分有向无环图 (completed partially directed acyclic graph, CPDAG) 以一张部分定向图表示一个有向图等价类：类内所有有向图都具有的方向画为箭头，其余边画为无向边。它也称观测本质图。CPDAG 中未定向边的选择相互约束，不能逐条任意定向；完成后的图必须无环，并且不增加新的无屏蔽碰撞结构。本文说“恢复 CPDAG”，指恢复等价类的这些不变信息，而不是挑选一个代表后把其余方向也当作证据。

无向图没有方向选择，但仍有 $2^{\binom{d}{2}}$ 种简单图。有向图除邻接外还需选择方向并排除有向环；仅固定一个拓扑序，就已有 $2^{\binom{d}{2}}$ 种边集可选。含不同端点标记的混合图可以表达潜变量边缘化后的结构，其合法性也受到全局限制。因此，模型的表达能力、参数量和搜索代价必须一起考虑：较大

的图族能容纳更多分布，却要求更多数据，也更难遍历。若还需频繁推断，树宽等计算性质可以成为明确的候选约束，但不能把这种工程约束说成从数据中发现的事实。

25.2 有向图结构学习

同一组数据既可以接受条件独立检验，也可以用于计算似然。前者把结构证据写成“给定哪些变量后可以删去联系”，后者把证据累积成候选图的分数。搜索可以只依靠一种证据，也可以组合二者；它不是与检验、评分并列的第三种统计假设。

25.2.1 条件独立约束

为了从独立性反推边，需要假定分布中的条件独立恰好来自某张有向图的 d-分离。这称为**忠实性** (faithfulness)：图上的 d-连接不会因参数抵消而产生额外独立性。在这个假设下，找到了使 X_i 与 X_j 条件独立的集合 $S \subseteq V \setminus \{i, j\}$ ，就有理由删去 i, j 之间的边。有限样本中未知的是条件分布，因此算法实际检验

$$H_0 : X_i \perp X_j \mid \mathbf{X}_S,$$

并把未拒绝 H_0 暂作删边依据。未拒绝不等于证明独立；如果检验没有足够功效，真实但较弱的联系也可能被删去。

有限离散变量可使用分层列联表。令 $N_{a,b,s}$ 为 $(X_i, X_j, \mathbf{X}_S) = (a, b, s)$ 的样本数，点号表示对相应指标求和。似然比检验统计量为

$$G^2 = 2 \sum_{a,b,s: N_{a,b,s} > 0} N_{a,b,s} \log \frac{N_{a,b,s} N_{\cdot, \cdot, s}}{N_{a, \cdot, s} N_{\cdot, b, s}}. \quad (25.1)$$

在各单元概率为正、样本足够且变量状态数固定时，它在原假设下渐近服从卡方分布；若条件变量共有 q_S 种配置，自由度为 $q_S(r_i - 1)(r_j - 1)$ ，其中 r_i, r_j 为两端状态数。小样本、结构性零单元或许多稀有配置会破坏这项近似，不能只把自由度代入软件就认为检验可靠。

条件互信息 (conditional mutual information) 衡量给定条件后，联合分布偏离条件边缘乘积的程度。对有限离散变量，其定义为

$$I(X_i; X_j \mid \mathbf{X}_S) = \sum_{a,b,s} p(a, b, s) \log \frac{p(a, b \mid s)}{p(a \mid s)p(b \mid s)}.$$

求和只计入正概率项；这一量是各条件配置下 KL 散度的加权平均，非负且恰在条件独立时为零。以经验频率代入就得到 $\hat{I} = G^2/(2n)$ 。 S 为空时，条件互信息退化为**互信息** (mutual information)，衡量两端的边缘依赖；较大的互信息不一定表示存在一条直接边。

对联合高斯变量，条件独立等价于偏相关 $\rho_{i,j|S} = 0$ 。偏相关是分别用 $\mathbf{X}_S$ 线性回归两端以后，两个残差的相关系数；这给出了直接的计算办法。样本偏相关 $\hat{\rho}$ 经 Fisher 变换得到

$$Z = \frac{\sqrt{n-|S|-3}}{2} \log \frac{1 + \hat{\rho}_{i,j|S}}{1 - \hat{\rho}_{i,j|S}},$$

在相应正则条件下近似服从标准正态分布。非高斯分布中，零偏相关通常不够；核条件独立检验可以考察更丰富的非线性关系，但核、正则化和零分布校准都会影响结论。也不能用一般回归残差“不相关”来代替原变量的条件独立。

为使后续比较可以复核，本章使用三个二值测量量 X_1, X_2, X_3 。它们可理解为同一设备的三项状态指示，但不沿用前章故障模型的参数。表 25.1 是专为计算构造的 100 条记录，不是真实测量结果。每个变量都恰有 50 个 0 和 50 个 1。

x_1	x_2	x_3	次数	x_1	x_2	x_3	次数
0	0	0	36	1	0	0	4
0	0	1	9	1	0	1	1
0	1	0	1	1	1	0	9
0	1	1	4	1	1	1	36

表 25.1 人工构造的二值数据。记录恰好匹配公平根变量经过两次独立翻转的分布，两次翻转概率分别为 0.1 和 0.2。这只是生成数据的一种表示，不能由该表唯一确定因果方向。

将经验频率记为 $\hat{p}$ 。表中 $\hat{p}(X_1 = 1, X_3 = 1) = 0.37 \neq 0.25$ ，两端有边缘依赖；但给定 $X_2 = 0$ 时，

$$\hat{p}(X_1 = 0, X_3 = 0 | X_2 = 0) = \frac{36}{50} = \frac{45}{50} \frac{40}{50}.$$

这一层的其余三格也满足乘积分解， $X_2 = 1$ 层同样如此。因此经验条件互信息为零，式 (25.1) 给出 $G^2 = 0$ 。这是人为设计的精确等式；一般样本即使来自条件独立分布，也不会恰好满足它。

PC 算法 (PC algorithm) 把这类局部检验组织成结构恢复过程。它从完全无向图出发，按 $|S| = 0, 1, \dots$ 增加条件集大小；对尚相邻的 i, j ，从 i 的当前邻接集合去掉 j 后选取 S ，也考察交换两端后的候选。一旦未拒绝条件独立，就删边并记录一个分离集 $\text{Sep}(i, j)$ 。当所有相邻点对都没有足够大的候选邻接集合时，骨架阶段停止。在忠实性及准确独立性判定下，这种邻域搜索足以找到所需分离集，避免枚举所有节点子集。

骨架确定以后，对每个无屏蔽三元组 $i - k - j$ ，若 $k \notin \text{Sep}(i, j)$ ，就将其定向为 $i \rightarrow k \leftarrow j$ 。随后反复应用保持等价类的定向规则。例如，已有

$i \rightarrow k - j$ 且 i, j 不相邻时, $k - j$ 必须成为 $k \rightarrow j$, 否则会引入一个此前未确认的碰撞; 已有 i 到 j 的有向路径时, 边 $i - j$ 不能定为 $j \rightarrow i$, 否则形成有向环。完整实现需要完整的定向规则集, 不是只执行这两个示意规则; 在总体判定正确时, 最终得到 CPDAG。PC 的高维高斯一致性分析明确依赖稀疏性及非零偏相关不能过小等条件²。

对表 25.1, 三对变量的边缘检验统计量为

$$G_{1,2}^2 \approx 73.6128,$$

$$G_{2,3}^2 \approx 38.5490,$$

$$G_{1,3}^2 \approx 24.0181.$$

若用显著性水平 0.05 的渐近检验演示流程, 它们都超过自由度为 1 时的临界值 3.841。给定 X_2 后, 两端的条件检验统计量为零, 于是删除 1-3 边, 记录分离集 $\text{Sep}(1, 3) = \{2\}$ 。结果为 1-2-3, 没有证据选择图 25.1 中的某一个方向。此例条件表含稀有格, 仅用于展示流程, 不据此保证小样本卡方校准准确。

若一次检验误把 1,3 判为边缘独立, 记录的分离集会变为空集, 接着就可能错误地定向为碰撞结构。误删边还会缩小后续可搜索的邻接集合, 改变后面的检验和定向。有限样本实现须记录冲突处理与节点处理顺序, 必要时采用稳定化的邻接更新, 而不能假定所有检验决定总能组成合法 CPDAG。

25.2.2 结构评分与后验

条件独立检验一次回答一个问题, 评分则问一张图对全部数据的解释是否值得其复杂度。在观测完整且模型不含潜变量的离散设定下, 设 X_i 有 r_i 个状态, 其父集共有 q_i 种配置。令 $N_{i,j,k}$ 统计节点 i 取第 k 个状态且父集取第 j 种配置的次数, $N_{i,j} = \sum_k N_{i,j,k}$ 。在各条件概率表自由变化时, 最大似然对数得分为

$$\ell(\hat{\theta}_{\mathcal{G}}; \mathcal{D}) = \sum_{i=1}^d \sum_{j=1}^{q_i} \sum_{k=1}^{r_i} N_{i,j,k} \log \frac{N_{i,j,k}}{N_{i,j}}. \quad (25.2)$$

零计数项按 $0 \log 0 = 0$ 处理; 若一整行未出现, 该行条件分布不由数据决定, 不能真的计算 $0/0$ 。对数似然按节点分解, 所以改动一个父集只改变相应局部项。

但未惩罚似然会奖励多余边。若 $\mathcal{M}(\mathcal{G}_1) \subseteq \mathcal{M}(\mathcal{G}_2)$, 最大化后必有 $\ell_2 \geq \ell_1$; 更大的模型至少可以把新增依赖的参数设成无作用。因此, 未惩罚最大似然适合在复杂度已固定的模型之间比较, 一般结构选择还需要复杂度控制。**贝叶斯信息准则** (Bayesian information criterion, BIC) 在本章采用越

² M. Kalisch, P. Bühlmann, *Estimating High-Dimensional Directed Acyclic Graphs with the PC-Algorithm* In Journal of Machine Learning Research, 2007, vol. 8, pp. 613–636

大越好的记号：

$$\begin{aligned} \text{Score}_{\text{BIC}}(\mathcal{G}) &= \ell(\hat{\theta}_{\mathcal{G}}; \mathcal{D}) - \frac{k_{\mathcal{G}}}{2} \log n, \\ k_{\mathcal{G}} &= \sum_i q_i(r_i - 1). \end{aligned} \quad (25.3)$$

常见软件把它乘以 -2 并最小化，二者排序相同。这里 $k_{\mathcal{G}}$ 是自由参数数目，不是边数。BIC 作为对数边缘似然的渐近近似，需要固定维数、内部参数和非奇异信息矩阵等正则条件；潜变量模型往往不满足这些条件。

最小描述长度 (minimum description length, MDL) 从编码角度作同样的权衡：用多少信息描述模型，又用多少信息描述模型没有预测好的数据。某些 MDL 近似产生与 BIC 相同的主导惩罚，但具体编码还可能包含图结构的码长，不应把所有 MDL 评分都写成唯一的 BIC 公式。无论选哪种准则，都须固定参数化、复杂度定义及得分方向后再进行搜索。

表 25.1 中，独立模型有 3 个参数，任一无碰撞链有 5 个，完整三节点有向图有 7 个。以自然对数计算，三者的最大对数似然分别为 -207.9442 、 -151.8633 、 -151.8633 。完整图虽然能表示更多分布，对这张特制的表却没有额外拟合收益。对应 BIC 为 -214.8519 、 -163.3762 、 -167.9814 ，所以链优于完整图。这个比较选择了依赖复杂度，却仍没有区分三种等价方向。

另一种办法不先把参数优化为一点，而是把它积分掉。**边缘似然** (marginal likelihood) 是参数先验下的平均数据似然，结构后验据此写成

$$\begin{aligned} p(\mathcal{D} | \mathcal{G}) &= \int p(\mathcal{D} | \theta, \mathcal{G}) p(\theta | \mathcal{G}) d\theta, \\ p(\mathcal{G} | \mathcal{D}) &\propto p(\mathcal{D} | \mathcal{G}) p(\mathcal{G}). \end{aligned} \quad (25.4)$$

它奖励能在先验支持的较大参数区域内解释数据的结构，而不是只奖励某个极窄区域内的最佳拟合；这种复杂度控制也意味着先验不可忽略。

比较两个候选结构时，**Bayes 因子** (Bayes factor) 是它们的边缘似然之比，衡量数据使两者的相对支持改变了多少。设模型内参数先验均已归一化，两个边缘似然有限，且第二个严格为正，则

$$\begin{aligned} \text{BF}_{12} &= \frac{p(\mathcal{D} | \mathcal{G}_1)}{p(\mathcal{D} | \mathcal{G}_2)}, \\ \frac{p(\mathcal{G}_1 | \mathcal{D})}{p(\mathcal{G}_2 | \mathcal{D})} &= \text{BF}_{12} \frac{p(\mathcal{G}_1)}{p(\mathcal{G}_2)}. \end{aligned} \quad (25.5)$$

第二式还要求结构先验 $p(\mathcal{G}_2) > 0$ ，且全体候选结构给出的数据证据有限而为正。左侧是后验赔率，右侧将它分成数据贡献与结构先验赔率。Bayes 因子依赖各结构内部的参数先验，却不包含外层结构先验赔率。例如 $\text{BF}_{12} = 3$ 而先验赔率为 $1/2$ 时，后验赔率为 $3/2$ ，不是 3。

仍在观测完整且模型不含潜变量的离散设定下，若各条件表行参数

$\theta_{i,j}$ 在先验下独立, 并采用狄利克雷先验 $\theta_{i,j} \sim \text{Dir}(\alpha_{i,j,1}, \dots, \alpha_{i,j,r_i})$, 其中 $\alpha_{i,j,k} > 0$ 且 $\alpha_{i,j} = \sum_k \alpha_{i,j,k}$, 积分可精确计算。每行似然与先验相乘后, $\theta_{i,j,k}$ 的指数从 $\alpha_{i,j,k} - 1$ 变成 $\alpha_{i,j,k} + N_{i,j,k} - 1$, 所以积分就是更新前后狄利克雷归一化常数之比。各行相乘得到

$$p(\mathcal{D} | \mathcal{G}) = \prod_{i,j} \frac{\Gamma(\alpha_{i,j})}{\Gamma(\alpha_{i,j} + N_{i,j})} \prod_k \frac{\Gamma(\alpha_{i,j,k} + N_{i,j,k})}{\Gamma(\alpha_{i,j,k})}. \quad (25.6)$$

这里 $\mathcal{D}$ 是逐条记录的样本, 故没有另乘一个依结构改变的多项式计数系数。任意指定各行狄利克雷超参数都可得到这类贝叶斯狄利克雷评分, 但不一定具有评分等价性。

贝叶斯狄利克雷等价评分 (Bayesian Dirichlet equivalent score, BDe) 要求等价有向图取得相同边缘似然。实现它的一种方式是给出一个严格为正的先验联合分布 p_0 和共同的**等效样本量** (equivalent sample size) $\alpha > 0$, 按每个候选父集的边缘概率设置

$$\alpha_{i,j,k} = \alpha p_0(X_i = k, \mathbf{X}_{\text{pa}(i)} = j).$$

式中的 j, k 在这里代表相应配置的编号。这些伪计数来自同一个联合分布, 而不是在每张图上互不协调地指定。结合参数独立性、参数模块性和似然等价性假设, 可得到等价图相同的积分; 若结构先验 $p(\mathcal{G})$ 在类内不同, 结构后验仍可不同, 不能把先验造成的偏好归因于数据³。

均匀 BDe 评分 (BDe uniform, BDeu) 取均匀 p_0 , 于是 $\alpha_{i,j,k} = \alpha/(q_i r_i)$ 。这是 BDe 的特例, 不意味着每张图的结构先验均匀, 也不意味着每个条件表行有相同的总伪样本量 α ; 每行实际只有 α/q_i 。例如二值 X_2 有一个二值父节点且 $\alpha = 4$ 时, 每格伪计数为 1。表中的父状态 $X_1 = 0$ 对应 (45, 5) 次观测, 后验均值为 (46/52, 6/52), 而不是最大似然估计的 (0.9, 0.1)。增加父节点会增加 q_i , 把同一总量分散到更多配置; 数据稀疏时, 不同 α 可能显著改变结构排序, 应报告敏感性。

仍取 $\alpha = 4$, 将表 25.1 的计数代入式 (25.6), 正向链、分叉和反向链的对数边缘似然均约为 -161.968668。这一数值既可复核公式, 也说明 BDeu 不会仅因把同一个无碰撞链改画成另一方向就奖励其中一张图。

如果多张图都能解释数据, 单一最优图会掩盖这种不确定性。**贝叶斯模型平均** (Bayesian model averaging, BMA) 按结构后验综合预测:

$$p(\mathbf{x}_{\text{new}} | \mathcal{D}) = \sum_{\mathcal{G} \in \mathcal{G}} p(\mathbf{x}_{\text{new}} | \mathcal{D}, \mathcal{G}) p(\mathcal{G} | \mathcal{D}).$$

每项预测还需积分参数后验。对“存在某条边”这样的结构特征, 也可把其指示函数按同一后验加权。实际计算常用结构采样或一组高分候选近似, 必须说明只覆盖了哪些图; 搜索多次得到同一图不等于已计算其后验

³ D. Heckerman, D. Geiger, D. M. Chickering, *Learning Bayesian Networks: The Combination of Knowledge and Statistical Data In Machine Learning*, 1995, vol. 20, no. 3, pp. 197–243

概率。对等价类平均时还要明确先验作用于有向图还是等价类，不能把类内图的数量差异悄悄忽略。

25.2.3 结构空间搜索

定义了评分，还没有解决怎样找到高分图。有向图局部搜索从一张满足约束的图开始，尝试加边、删边、反向三种操作；每个候选都要检查无环性和领域限制，然后接受得分最大的正增益操作。当没有合法改进时停止，所得只是该领域中的局部最优。加边只需更新一个局部评分，反向需更新两端评分；缓存父集得分可以减少重复计算，但不能消除全局无环约束。重启、禁忌搜索或更大邻域可以探索更多位置，不提供无条件的全局最优保证。

离散 BIC 还能把一次加边的得分变化写得很清楚。设向 X_i 的现有父集 P 加入 X_j ，用 $\hat{I}$ 表示经验条件互信息，则

$$\Delta \text{Score}_{\text{BIC}} = n\hat{I}(X_i; X_j | \mathbf{X}_P) - \frac{\Delta k}{2} \log n. \quad (25.7)$$

第一项来自条件熵的减少，第二项是新增自由参数的代价。表中从空图加入 $1 \rightarrow 2$ 时， $\hat{I}(X_1; X_2) = 0.368064$ ， $\Delta k = 1$ ，增益为 $36.8064 - 2.3026 = 34.5038$ 。互信息在这里进入评分，并不意味着算法正在执行固定显著性水平的独立性检验。已经确定的评分和执行移动的搜索仍是两个环节。

评分等价时，有向图搜索会反复走过得分相同的代表。**贪心等价搜索** (greedy equivalence search, GES) 把状态改为 CPDAG，在等价类之间先做前向插入，再做后向删除，各阶段都在没有正增益合法操作时停止。一次等价类操作可能同时规定若干端点方向，再完成为新的 CPDAG，不能简单理解为在当前画面上任意添一条箭头。GES 的理论保证依赖评分等价、局部一致性 & 真实分布存在有向图完美映射等条件，并不说明任何局部爬山法都能成功⁴。

当节点数允许时，也可以作精确搜索。对可分解评分，记 $s_i(P)$ 为节点 i 选择父集 P 的得分， $F(U)$ 为节点子集 U 上最佳有向图得分。任一非空有向图都有一个汇点，即没有出边的节点，所以

$$\begin{aligned} F(\emptyset) &= 0, \\ F(U) &= \max_{i \in U} \left\{ F(U \setminus \{i\}) + \max_{P \subseteq U \setminus \{i\}} s_i(P) \right\}. \end{aligned} \quad (25.8)$$

递推把 i 放在拓扑序末尾，剩余图与 i 的父集即可独立优化；枚举所有可能汇点就覆盖全部有向图。预计算最佳父集得分后，这类动态规划仍需处理指数多的子集，精确性是用时间和内存换来的。

整数规划则为每个候选父集设置二值变量 $z_{i,P}$ ，以 $\sum_{i,P} s_i(P) z_{i,P}$ 为目标，

⁴ D. M. Chickering, *Optimal Structure Identification with Greedy Search* In Journal of Machine Learning Research, 2002, vol. 3, pp. 507–554

并要求 $\sum_p z_{i,p} = 1$ 。还必须阻止所选父集组成环。例如对每个非空 $U \subseteq V$ 要求

$$\sum_{i \in U} \sum_{P: P \cap U = \emptyset} z_{i,p} \geq 1.$$

它要求每个诱导子图至少有一个在子图内无父节点的点；有向环的节点集合不满足这一条件，而有向图总满足。约束数量指数增长，求解器通常按需加入违反的约束。只有完成最优性认证，才可说得到所规定候选空间内的最优解；提前截断的父集空间同样限制结论。

连续优化改变的是搜索表示。令 $\mathbf{W} \in \mathbb{R}^{d \times d}$ 满足 $W_{i,j} \neq 0$ 对应 $i \rightarrow j$, $\mathbf{Y} \in \mathbb{R}^{n \times d}$ 为中心化数据矩阵，每行是一条样本。NOTEARS 把线性模型的拟合写成

$$\begin{aligned} \min_{\mathbf{W}} \quad & \frac{1}{2n} \|\mathbf{Y} - \mathbf{Y}\mathbf{W}\|_F^2 + \lambda \|\mathbf{W}\|_1, \\ \text{满足} \quad & h(\mathbf{W}) = \text{tr}(\exp(\mathbf{W} \circ \mathbf{W})) - d = 0. \end{aligned} \quad (25.9)$$

这里 $\circ$ 为逐元素乘积， $\exp$ 是矩阵指数，不是逐元素指数； $\|\mathbf{W}\|_1$ 表示所有元素绝对值之和。令 $\mathbf{B} = \mathbf{W} \circ \mathbf{W}$ ，则

$$h(\mathbf{W}) = \sum_{m=1}^{\infty} \frac{\text{tr}(\mathbf{B}^m)}{m!}.$$

$\mathbf{B}$ 非负，而 $\text{tr}(\mathbf{B}^m)$ 累加长度为 m 的闭合有向游走的权重。有向环存在时，至少某一项严格为正；无环时所有闭合游走都不存在，每项为零。这证明 $h(\mathbf{W}) = 0$ 与支撑图无环精确等价，也排除了自环。梯度为 $2\mathbf{W} \circ [\exp(\mathbf{W} \circ \mathbf{W})]^\top$ ，可交给增广拉格朗日等数值方法⁵。

可微不等于凸：无环可行集合仍然非凸，数值求解也不保证全局最优。停止容差下的 h 接近零不意味着阈值化后的图必然无环，须另作拓扑检查。平方损失采用线性拟合尺度，其统计识别性质还依赖噪声和模型假设；无环公式本身既不要求非高斯，也不赋予所选方向因果真实性。

混合方法可以先用条件独立信息筛选候选邻接或父集，再在缩小后的空间内优化 BIC、BDe 等评分。这样做减少搜索量，也把筛选阶段的漏边变成后续无法修复的限制。因而“使用 PC 式筛选、BIC 评分、有向图爬山搜索”是一套可组合的设计，不能把这些名字列成互斥模型类别。

25.2.4 观测缺失与结构 EM

如果某些记录没有测量 X_2 ，前面评分公式所需的 $N_{i,j,k}$ 就无法直接计数。此时观测似然对每条记录先边缘化未观测变量，不再按节点简单分解。删去不完整记录还可能改变样本分布。下文假定缺失机制可忽略，例如满足随机缺失并且缺失机制参数与模型参数可区分；若缺失取决于未观测值，通常必须把缺失指示机制也纳入模型。

⁵ X. Zheng, B. Aragam, P. Ravikumar, E. P. Xing, *DAGs with NO TEARS: Continuous Optimization for Structure Learning* In *Advances in Neural Information Processing Systems*, 2018

结构期望最大化 (structural expectation maximization, 结构 EM) 在当前图下推断缺失值, 再利用这些推断结果比较新图。与固定图的 EM 不同, M 步允许改变父集。以下以有限离散缺失变量为例, 记所有未观测量为 $\mathbf{Z}$, 观测记录为 $\mathcal{D}_{\text{obs}}$, 当前后验为

$$q^{(t)}(\mathbf{Z}) = p(\mathbf{Z} \mid \mathcal{D}_{\text{obs}}, \mathcal{G}^{(t)}, \boldsymbol{\theta}^{(t)}).$$

对某个候选图的节点家庭, 所需期望计数是

$$\bar{N}_{i,j,k}^{(t)} = \sum_{r=1}^n \mathbb{E}_{q^{(t)}} [\mathbf{1}\{X_{r,i} = k, \mathbf{X}_{r,\text{pa}_{\mathcal{G}}(i)} = j\}].$$

$X_{r,i}$ 表示第 r 条记录中的节点 i ; 已观测分量在期望中固定。候选图改变后, 所需联合后验作用域也可能改变, 因此 E 步不能只计算当前图已有边的边缘统计。

对惩罚似然版本, 在相同未观测变量空间上定义

$$\begin{aligned} Q^{(t)}(\mathcal{G}, \boldsymbol{\theta}) &= \mathbb{E}_{q^{(t)}} [\log p(\mathcal{D}_{\text{obs}}, \mathbf{Z} \mid \mathcal{G}, \boldsymbol{\theta})], \\ \mathcal{F}^{(t)}(\mathcal{G}, \boldsymbol{\theta}) &= Q^{(t)}(\mathcal{G}, \boldsymbol{\theta}) + H(q^{(t)}) - \text{pen}(\mathcal{G}). \end{aligned} \quad (25.10)$$

其中 $H(q^{(t)})$ 是缺失值后验的熵, 在本轮比较中固定。由 Jensen 不等式, $\mathcal{F}^{(t)}$ 是观测对数似然减惩罚的下界; 当 $q^{(t)}$ 为精确当前后验时, 下界在当前模型处相切。记第 t 轮模型的观测对数似然减惩罚为 $L^{(t)}$ 。只要搜索找到使 $Q^{(t)} - \text{pen}$ 不下降的新图及参数, 就有

$$\begin{aligned} L^{(t+1)} &\geq \mathcal{F}^{(t)}(\mathcal{G}^{(t+1)}, \boldsymbol{\theta}^{(t+1)}) \\ &\geq \mathcal{F}^{(t)}(\mathcal{G}^{(t)}, \boldsymbol{\theta}^{(t)}) = L^{(t)}. \end{aligned}$$

完全数据对数似然对计数线性, 所以此处用 $\bar{N}^{(t)}$ 替换计数能够精确构造 $Q^{(t)}$ 。这项单调性来自共同下界, 不是因为新图的补全数据似然看起来更大。

例如, 一条记录只观测到 $X_1 = X_3 = 0$, 当前模型取表 25.1 对应的链参数。 $X_2 = 0$ 和 1 的未归一化概率分别为 $0.5 \times 0.9 \times 0.8 = 0.36$ 及 $0.5 \times 0.1 \times 0.2 = 0.01$, 故后验为 $(36/37, 1/37)$ 。这条记录给相应家庭计数贡献分数, 而不是把缺失值硬填成 0。若当前结构错了, 这些软计数也可能持续偏向错误解释, 结构 EM 仍可能停在局部解。

贝叶斯结构 EM 还涉及参数积分。对固定且可比较的未观测变量空间, 精确贝叶斯版本用当前模型下已积分参数的未观测变量后验, 对候选的完全数据对数边缘似然取期望, 再加入结构先验。式 (25.6) 含有非线性的 $\log \Gamma$, 一般有

$$\mathbb{E}[\log \Gamma(\alpha + N)] \neq \log \Gamma(\alpha + \mathbb{E}[N]).$$

因此，把期望计数直接代入 BDe 只是近似，不是精确观测边缘似然，也不能直接继承精确贝叶斯结构 EM 的单调性。Friedman 分别给出了贝叶斯结构 EM 的理论框架及实际计算所需近似⁶。

近似 E 步同样需要区分目标：变分 E 步可以改善自身下界，但未必提高真实观测似然；采样误差也可能导致错误接受结构。增加潜变量或改变潜在状态数会改变隐空间，不能不经处理沿用上面的相切下界证明。实践中常固定一组候选潜变量再优化，或者对新增候选单独初始化、拟合和比较。潜变量的标签置换、观测等价和其他不可识别性不会因重复 E 步消失。

⁶ N. Friedman, *The Bayesian Structural EM Algorithm* In Proceedings of the Fourteenth Conference on Uncertainty in Artificial Intelligence, 1998, pp. 129–138

25.3 无向图结构学习

无向图的学习目标是条件依赖，不必解决箭头方向。困难仍取决于允许哪种分布和相互作用：树的分解产生一个组合优化特例，高斯分布把结构映射为矩阵的零元素，一般离散模型则要同时处理特征选择和归一化。

25.3.1 树结构与 Chow-Liu 算法

对有限离散变量，若只允许树上的成对因子，每个候选树都只保留 $d - 1$ 条边。将树任选一个根并向外定向，它没有碰撞点，因而既可写成无向树分解，也可写成每个非根节点只有一个父节点的有向图。选择这个根只是计算表示，不是因果定向。

设 $\mathcal{T} = (V, E_{\mathcal{T}})$ 是一棵生成树，经验单点边缘为 $\hat{p}_i$ ，成对边缘为 $\hat{p}_{i,j}$ 。只要每个声明状态的经验单点概率严格为正，固定树的最大似然分布就可写为

$$\hat{p}_{\mathcal{T}}(\mathbf{x}) = \prod_{i=1}^d \hat{p}_i(x_i) \prod_{\{i,j\} \in E_{\mathcal{T}}} \frac{\hat{p}_{i,j}(x_i, x_j)}{\hat{p}_i(x_i) \hat{p}_j(x_j)}. \quad (25.11)$$

边因子修正了独立模型遗漏的成对关系。与一般图上的成对因子不同，这个表达式已经归一化，不需要另求配分函数；原因就在于树可以从叶子逐个消去。

定理 25.1 Chow-Liu 最优树 设 $V = \{1, \dots, d\}$ 为有限节点集合，每个 X_i 取值于有限非空状态空间，数据由 $n \geq 1$ 条完整记录组成。假定每个声明状态 a 均有 $\hat{p}_i(a) > 0$ ；成对经验边缘允许取零。候选模型类由 V 上的全部生成树及其不受额外参数约束的局部概率表组成。定义自然对数下的经验互信息

$$\hat{I}(X_i; X_j) = \sum_{a,b} \hat{p}_{i,j}(a, b) \log \frac{\hat{p}_{i,j}(a, b)}{\hat{p}_i(a) \hat{p}_j(b)}.$$

其中 $\hat{p}_{i,j}(a, b) = 0$ 的项按 $0 \log 0 = 0$ 解释。以 $\hat{I}(X_i; X_j)$ 为边权，任一

最大权生成树 $\mathcal{T}^*$ 及式 (25.11) 给出的分布，构成树族内的全局最大似然解。

证明. 固定树 $\mathcal{T}$ 并选择根 o ，用 $\pi(i)$ 表示非根节点 i 唯一的父节点。任一树分布可写为

$$q_{\mathcal{T}}(\mathbf{x}) = q_o(x_o) \prod_{i \neq o} q_i(x_i | x_{\pi(i)}).$$

对数似然分解为根边缘和每条条件表行的对数似然。各行分别受“概率之和为 1”约束，独立极大化得到 $q_o = \hat{p}_o$ 及 $q_i = \hat{p}_{i,\pi(i)} / \hat{p}_{\pi(i)}$ 。单点边缘的严格正性保证分母非零；零频成对单元只会使相应条件概率为零，不影响归一化或最优性。这些都是归一化的条件概率，由叶到根求和可知乘积也是归一化分布。将其整理，便得到式 (25.11)；这同时证明了固定树上参数解的最优性。

记 $\hat{H}(X_i) = -\sum_a \hat{p}_i(a) \log \hat{p}_i(a)$ 。将上述分布代入经验平均对数似然，并按单点和边的作用域求和，得到

$$\begin{aligned} \frac{1}{n} \ell(\hat{p}_{\mathcal{T}}; \mathcal{D}) &= \mathbb{E}_{\hat{p}}[\log \hat{p}_{\mathcal{T}}(\mathbf{X})] \\ &= -\sum_i \hat{H}(X_i) + \sum_{\{i,j\} \in E_{\mathcal{T}}} \hat{I}(X_i; X_j). \end{aligned} \quad (25.12)$$

熵项与树无关，所以树族中的最优结构正是互信息边权和最大的生成树。每个候选树的最佳参数都已包含在比较中，故这不是仅在某组固定参数下的结构最优。

最大权生成树可用按权重递减加边的 Kruskal 算法得到，加入边时跳过会形成环的选择，同权边可按固定节点顺序处理。其最优性可由交换论证说明：设已选森林包含在某棵最优树中，新选边 e 连接森林的两个分量。若最优树不含 e ，把 e 加入会形成环；环上必有另一条边 f 跨过相应分量边界且不在当前森林中。 f 在本轮也是可选边，故 $w(e) \geq w(f)$ 。以 e 替换 f 不会降低总权重，仍得到包含新森林的最优树。归纳到选满 $d-1$ 条边，算法输出即为最优树。 ■

也可以从分布逼近看这个结果： $\text{KL}(\hat{p} \parallel \hat{p}_{\mathcal{T}})$ 等于式 (25.12) 右侧的负值再减去 $\hat{H}(\mathbf{X})$ ，后者同样不依赖树。因此，最大似然树也是对经验分布的最小 KL 树近似。把经验边缘换成给定总体分布的边缘，同一证明给出总体版本。这一经典结果由 Chow 与 Liu 提出⁷。

表 25.1 的三个单点熵均为 $\log 2$ 。 X_1, X_2 不相等的频率为 0.1， X_2, X_3 为

⁷ C. K. Chow, C. N. Liu, *Approximating Discrete Probability Distributions with Dependence Trees* In IEEE Transactions on Information Theory, 1968, vol. 14, no. 3, pp. 462–467

0.2, X_1, X_3 为 0.26。对均匀二值边缘, 若不同值概率为 ε , 则

$$\hat{I} = \log 2 - h_b(\varepsilon),$$

$$h_b(\varepsilon) = -\varepsilon \log \varepsilon - (1 - \varepsilon) \log(1 - \varepsilon).$$

三条边权依次为 0.368064、0.192745、0.120090, 所以选 1-2 和 2-3, 如图 25.2。1-3 的边缘依赖不弱, 却可由经过 2 的路径解释; 按边缘相关非零就全部连边, 会错过这项区别。




图 25.2 同一计数表产生的三个互信息边权, 单位为 nat。实线为最大权生成树保留的边, 虚线为未选边。树分布在此例恰好复原经验分布, 但算法一般只能给出最佳树近似。

选根为 1 时, 所得模型取 $p(X_1 = 1) = 0.5$, 沿两条边分别以 0.1、0.2 的概率翻转。于是 $\hat{p}_{\mathcal{T}}(0, 0, 0) = 0.5 \times 0.9 \times 0.8 = 0.36$, 与表中一致; 每条记录平均对数似然为 $-3 \log 2 + 0.368064 + 0.192745 = -1.518633$, 也复核了前面的 BIC 比较。

严格正边缘让证明免于处理零分母。若有零计数, 可在经验支持上定义条件表, 对从未出现的条件配置任取归一化版本, 并采用 $0 \log 0 = 0$ 延伸似然结论; 若改用平滑伪计数, 则优化的是平滑后的目标, 不能仍声称是原记录的未惩罚最大似然估计。一般离散树的参数数目为

$$\sum_i (r_i - 1) + \sum_{\{i, j\} \in E_{\mathcal{T}}} (r_i - 1)(r_j - 1).$$

只有各节点状态数相同等情形下, 所有树的维数才相同。即使状态数不同, Chow-Liu 仍精确优化树族内似然, 但若要作 BIC 选择, 就应从每条互信息边权中扣除相应的参数惩罚。

树假设换来了高效的结构优化和推断, 却排除了环及不可约高阶作用。即使总体图不是树, 算法也会返回一棵树; “最优” 只相对于候选树族。互信息接近时, 有限样本可改变排序; 零权边也可能仅为连接全部节点而被

选入。允许森林并惩罚边数，可以不强迫所有变量相连。

25.3.2 高斯图结构学习

对非退化联合高斯变量, $\mathbf{X} \sim \mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ 且 $\boldsymbol{\Sigma} \succ 0$, 图结构可以直接从**精度矩阵** (precision matrix) $\mathbf{K} = \boldsymbol{\Sigma}^{-1}$ 读取:

$$X_i \perp X_j \mid \mathbf{X}_{V \setminus \{i,j\}} \iff K_{i,j} = 0.$$

这与协方差零表示边缘独立不同。一般连续分布中, 逆协方差的零元素也没有相同的条件独立保证。

令 $\hat{\boldsymbol{\Sigma}} = n^{-1} \sum_r (\mathbf{x}_r - \bar{\mathbf{x}})(\mathbf{x}_r - \bar{\mathbf{x}})^\top$ 。舍去常数并缩放后, 高斯负对数似然为 $-\log \det \mathbf{K} + \text{tr}(\hat{\boldsymbol{\Sigma}} \mathbf{K})$ 。直接求逆在 n 小于维数时可能不可行, 在有限样本中也很少得到精确零。**图 Lasso** (graphical lasso) 加入稀疏惩罚:

$$\hat{\mathbf{K}} = \arg \min_{\mathbf{K} \succ 0} \left\{ -\log \det \mathbf{K} + \text{tr}(\hat{\boldsymbol{\Sigma}} \mathbf{K}) + \lambda \sum_{i \neq j} |K_{i,j}| \right\}. \quad (25.13)$$

这里不惩罚对角元, 惩罚同时计入两个对称非对角元素; 与另一种仅对 $i < j$ 求和的实现比较时应换算 λ 。正定约束保证合法高斯分布, ℓ_1 惩罚使部分非对角元恰好为零。该目标是凸的, 但图恢复仍需要统计条件; 一个可靠的凸求解器只能消除优化误差, 不能消除抽样误差⁸。

也可逐节点估计邻域。高斯条件均值满足

$$\mathbb{E}[X_i \mid \mathbf{X}_{-i}] = \mu_i + \sum_{j \neq i} \left(-\frac{K_{i,j}}{K_{i,i}} \right) (X_j - \mu_j),$$

其中 $-i$ 表示除 i 外的所有节点。因此, 对每个节点作稀疏线性回归, 可以用非零回归系数估计邻居。两次回归对同一条边可能意见不同, 取并集的 OR 规则偏向保留边, 取交集的 AND 规则更保守。分别回归不自动给出对称正定的精度矩阵; 若最终还要联合密度和推断, 应另作相容参数拟合。

例如

$$\mathbf{K} = \begin{pmatrix} 2 & -1 & 0 \\ -1 & 2 & -1 \\ 0 & -1 & 2 \end{pmatrix}, \quad \boldsymbol{\Sigma} = \frac{1}{4} \begin{pmatrix} 3 & 2 & 1 \\ 2 & 4 & 2 \\ 1 & 2 & 3 \end{pmatrix}.$$

两矩阵相乘为单位矩阵, $\mathbf{K}$ 的顺序主子式为 2, 3, 4, 故正定。 $\Sigma_{1,3} = 1/4$ 虽非零, $K_{1,3} = 0$ 却说明给定 X_2 以后两端独立。节点 1 的回归只保留 X_2 , 系数为 1/2; 节点 2 对两端的系数均为 1/2, 恢复同一个无向链。实际选择 λ 时, 预测误差最小的值不一定最利于精确选边, 应区分预测调参与结构恢复目标。

⁸ J. Friedman, T. Hastie, R. Tibshirani, *Sparse Inverse Covariance Estimation with the Graphical Lasso* In *Biostatistics*, 2008, vol. 9, no. 3, pp. 432–441

25.3.3 离散与高阶 Markov 网络结构学习

离散无向模型通常没有一个矩阵逆可以直接给出图。可先建立候选特征字典 $\{f_a(\mathbf{x}_{C_a})\}$, 其中 $C_a \subseteq V$ 是特征作用域, 再写成严格为正的有限状态模型

$$p_{\theta}(\mathbf{x}) = \exp\left\{\sum_a \theta_a f_a(\mathbf{x}_{C_a}) - A(\theta)\right\}.$$

选哪些非零参数, 就是选哪些相互作用; 若每个候选作用域有一组编码参数, 可以用组稀疏惩罚整体选择该因子。需要先规定可识别的编码或对比约束, 否则同一分布的不同参数写法可能改变“哪些系数为零”。一个高阶因子还会把其作用域在无向图中补成团, 因子集合比单纯边集保留了更细的建模信息。

完整似然加稀疏惩罚可写为

$$\min_{\theta} \left\{ A(\theta) - \sum_a \theta_a \hat{\mathbb{E}}[f_a] + \lambda \|\theta\|_1 \right\}.$$

计算梯度需要模型期望, 也就需要推断; 当候选作用域形成大团或大树宽时, 这项代价会在每次优化中重复出现。另一条路线是**伪似然** (pseudo-likelihood), 以 $\prod_{r,i} p_{\theta}(\mathbf{x}_{r,i} | \mathbf{x}_{r,-i})$ 代替联合似然。单点条件概率只需在 X_i 的状态上归一化, 避开全局配分函数, 但这不是原联合似然, 也不自动继承其效率或有限样本性质。

例如对 $x_i \in \{-1, 1\}$ 的成对 Ising 模型, 定义局部场 $u_i = b_i + \sum_{j \neq i} J_{i,j} x_j$, 则

$$\log \frac{p(X_i = 1 | \mathbf{x}_{-i})}{p(X_i = -1 | \mathbf{x}_{-i})} = 2u_i.$$

节点邻域选择于是成为稀疏逻辑回归。若联合优化对称参数 $J_{i,j} = J_{j,i}$, 所得条件概率来自共同联合模型; 若每个节点各拟合一组参数, 还需处理两端选择和参数相容性。评分搜索也可直接增加、删除候选因子, 但必须说明是在比较精确似然、近似似然还是伪似然。

只考察成对边缘可能完全漏掉高阶依赖。令

$$p(x_1, x_2, x_3) = \frac{\exp(\theta x_1 x_2 x_3)}{8 \cosh \theta}, \quad x_i \in \{-1, 1\}, \quad \theta \neq 0.$$

对任一变量求和, 分子变为 $2 \cosh \theta$, 所以任意一对的边缘均为 $1/4$, 成对互信息全为零。但 $\mathbb{E}[X_1 X_2 X_3] = \tanh \theta \neq 0$, 且给定 X_3 后 X_1, X_2 仍有相互作用。该分布严格为正, 没有借助零概率事件; 它需要三阶特征, 不能由所有成对边缘的独立性得出联合独立。允许大小不超过 m 的作用域时, 仅候选子集就有 $\sum_{\ell=1}^m \binom{d}{\ell}$ 个, 每个离散作用域内部还可能多个参数, 搜索与样本需求都会增长。

25.3.4 潜变量结构

一张稠密的观测图可能来自许多直接相互作用，也可能只是若干共同未观测变量的结果。对联合高斯向量，把节点分成观测集合 O 和潜变量集合 H ，联合精度矩阵按这两个集合分块。对潜变量积分，或在二次型中配方，可得到观测边缘精度矩阵

$$\begin{aligned}\mathbf{K}_{\text{marg}} &= (\boldsymbol{\Sigma}_{O,O})^{-1} \\ &= \mathbf{K}_{O,O} - \mathbf{K}_{O,H} \mathbf{K}_{H,H}^{-1} \mathbf{K}_{H,O} \\ &= \mathbf{S} - \mathbf{L}.\end{aligned}\quad (25.14)$$

$\mathbf{S} = \mathbf{K}_{O,O}$ 是给定潜变量后的条件精度矩阵，而 $\mathbf{L} \geq 0$ 且 $\text{rank}(\mathbf{L}) \leq |H|$ 。若条件图稀疏、有效潜变量少，便得到常称的**稀疏加低秩分解**（sparse plus low-rank decomposition）；按这里的半正定约定，公式实际上是稀疏项减低秩项。

一个可复核的例子是 $X_i = Z + \varepsilon_i$ ， $i = 1, 2, 3$ ，其中 $Z, \varepsilon_1, \varepsilon_2, \varepsilon_3$ 为相互独立的标准高斯变量。给定 Z 后三个 X_i 独立，但边缘协方差为 $\mathbf{I} + \mathbf{1}\mathbf{1}^\top$ ，由直接相乘可验证

$$\mathbf{K}_{\text{marg}} = \mathbf{I} - \frac{1}{4} \mathbf{1}\mathbf{1}^\top.$$

非对角元全为 $-1/4$ ，所以只看观测量得到完整条件依赖图；这里 $\mathbf{S} = \mathbf{I}$ ， $\mathbf{L} = \mathbf{1}\mathbf{1}^\top/4$ 的秩为 1。稠密观测依赖和给定潜变量后的独立并不矛盾。

令 $\hat{\boldsymbol{\Sigma}}_{O,O}$ 为观测样本协方差，可以求解

$$\begin{aligned}\min_{\mathbf{S}, \mathbf{L}} \quad & -\log \det(\mathbf{S} - \mathbf{L}) + \text{tr}(\hat{\boldsymbol{\Sigma}}_{O,O}(\mathbf{S} - \mathbf{L})) \\ & + \lambda(\gamma \|\mathbf{S}\|_1 + \text{tr}(\mathbf{L})), \\ \text{满足} \quad & \mathbf{S} - \mathbf{L} > 0, \quad \mathbf{L} \geq 0.\end{aligned}\quad (25.15)$$

此处 $\|\mathbf{S}\|_1$ 为逐元素绝对值之和，包含对角项； $\gamma > 0$ 调节两种惩罚的相对强度。半正定矩阵的核范数等于迹，因此第二个惩罚鼓励低秩。该凸程序的可识别性与恢复理论要求稀疏结构和低秩结构足够可区分，例如潜变量影响应分散到较多观测节点，不能本身又集中成很稀疏的模式⁹。

即使精确知道 $\mathbf{K}_{\text{marg}}$ ，分解也不总唯一：既稀疏又低秩的分量可以在两项之间移动而保持差不变。可识别条件满足时， $\mathbf{L}$ 的秩刻画有效潜在维数；它不自动等于全部物理隐因数量，潜变量的旋转、重参数化和具体含义还可能无法确定。完整潜变量图、给定潜变量后的观测条件图 $\mathbf{S}$ ，以及边缘化后的观测图 $\mathbf{K}_{\text{marg}}$ 是三个不同对象。此处的低秩表示是一种统计分解，不是潜在因果图已被恢复的证明。

⁹ V. Chandrasekaran, P. A. Parrilo, A. S. Willsky, *Latent Variable Graphical Model Selection via Convex Optimization* In The Annals of Statistics, 2012, vol. 40, no. 4, pp. 1935–1967

25.4 因果发现

前面的目标是表示分布。若还要判断改变一个变量会不会影响另一个变量，就必须给图增加干预含义。不同发现方法所用的信息不相同，其输出应与能成立的识别结论绑定，而不是一律画成“真实因果网络”。

25.4.1 因果假设与识别目标

因果 Markov 性 (causal Markov condition) 要求观测分布相对于因果有向图满足 Markov 性质；前面引入的忠实性进一步排除不由 d-分离解释的额外独立性。前者允许沿图从机制推出独立性，后者允许从独立性反推图约束。例如两条因果路径的效应恰好抵消时，Markov 性仍可能成立，忠实性却失败。有限样本还会遇到近似抵消，检验可能难以区分极弱联系和零联系。

因果充分性 (causal sufficiency) 要求相对于当前节点集合的共同直接原因都已被观测，也就是没有未建模的潜在混杂。它不要求世界上所有变量都已被测量。通常还要假定因果过程无环、样本没有未建模的选择偏差，以及数据来自所声明的环境。若要借助函数形式突破等价类，还需线性、噪声独立、非高斯性等对应条件。这些假设不是换一个搜索器就能自动获得的。

在充分、无环且忠实的观测设置下，条件独立信息一般只识别 CPDAG。若允许潜变量，就需要把完整有向图边缘化后的关系表示出来。**最大祖先图** (maximal ancestral graph, MAG) 用有向边、双向边及在考虑选择偏差时的无向边，表示观测变量的条件独立关系，而不显式画出所有潜变量。它无有向环；若一条边在 i 端有箭头， i 不能是另一端的祖先；与无向边相接的节点不能再有任何箭头指入。其“最大”指任何不相邻点对都可被某组观测变量分离，不是边越多越好。混合图中的**m-分离** (m-separation) 按两侧箭头识别路径上的碰撞节点：路径活跃要求每个非碰撞节点不在条件集合中，每个碰撞节点自身或至少一个后代在条件集合中。不存在连接两端的活跃路径，才称被 m-分离。

部分祖先图 (partial ancestral graph, PAG) 表示一组 Markov 等价 MAG 的共同端点信息。尾端和箭头端表示类内不变的端点，圆圈表示该端点在类内尚不确定；圆圈不是“可能没有边”。在不考虑选择偏差时， $i \rightarrow j$ 表达祖先关系，未必是观测尺度下的一条直接因果机制； $i \leftrightarrow j$ 排除二者互为祖先，并与潜在混杂相容，不表示双向反馈； $i \circ \rightarrow j$ 只固定 j 端的箭头，不能把 i 端圆圈偷偷补成尾端。PAG 编码祖先关系和独立性层面的不确定性，不枚举潜变量个数和连线细节¹⁰。

¹⁰ J. Zhang, *Causal Reasoning with Ancestral Graphs* In Journal of Machine Learning Research, 2008, vol. 9, pp. 1437–1474

25.4.2 基于观测数据的因果发现

第 25.2 节已经说明了 PC 和 GES 如何使用检验或评分。它们在因果发现中的额外问题是：统计等价类能否解释为因果等价类。PC 在因果 Markov 性、忠实性、因果充分性、无环性及正确独立性判定下返回 CPDAG；有限样本检验只能给出该对象的估计。GES 也不凭评分消除观测等价：当评分等价、可分解且局部一致，真实分布忠实于候选族中的有向图，并满足相应固定维大样本条件时，其等价类搜索可恢复 CPDAG。这里的局部一致性是指，大样本时评分奖励加入当前模型确实遗漏的依赖，并惩罚多余依赖，不只是笼统地说“评分一致”。

允许潜在混杂时，PC 使用的邻域分离搜索不再有相同保证。**快速因果推断算法**（fast causal inference, FCI）扩展需要考察的分离集合，并使用祖先图的定向规则，在相应 Markov 性、忠实性和准确条件独立信息下输出 PAG。它可以容纳潜变量，标准框架也能处理所声明的选择机制，但并不因此免除其他假设。即使有无限观测数据，FCI 通常也不输出唯一完整因果有向图；把 PAG 中所有圆圈强制定向，会丢掉算法本来保留的不确定性。完整定向规则及其识别边界见 Zhang 的研究¹¹。

另一种方向信息来自分布形状，而不只是条件独立。**线性非高斯无环模型**（linear non-Gaussian acyclic model, LiNGAM）设

$$X_j = \sum_{i \in \text{pa}(j)} b_{j,i} X_i + \varepsilon_j,$$

其中图无环，扰动相互独立、方差有限且非零、分布非高斯，不存在未观测混杂。令 $\mathbf{B}$ 的第 (j, i) 个元素为 $b_{j,i}$ ， ε 为扰动向量，递归展开得到 $\mathbf{X} = (\mathbf{I} - \mathbf{B})^{-1} \varepsilon$ 。**独立成分分析**（independent component analysis, ICA）从混合观测中分离统计独立的源；在这里可以利用非高斯性区分扰动，再结合无环结构约束消除相关排列歧义，从而在模型条件下识别超出 MEC 的方向。线性高斯模型没有同样的信息，所以不能省去“非高斯”二字后仍保留结论¹²。

加性噪声模型（additive noise model, ANM）允许 $Y = f(X) + \varepsilon$ 且 $\varepsilon \perp X$ 。在适当的光滑性、非退化及可识别性条件下，正向能表示为独立加性噪声，并不意味着反向也能表示为 $X = g(Y) + \eta$ 且 $\eta \perp Y$ 。比较拟合残差与输入的独立性便可提供方向证据；这与仅比较回归误差不同。多变量版本还要求递归机制和相互独立的扰动。线性高斯等例外在两个方向上都可成立，不能声称所有非线性回归都能恢复真因果¹³。

25.4.3 基于干预数据的因果发现

对表 25.1，观测 $X_2 = 1$ 时， X_1 取 1 的频率为 0.9。这不能直接回答把 X_2 外部设置为 1 后， X_1 是否也会改变。若真实机制是 $X_1 \rightarrow X_2 \rightarrow X_3$ ，设置

¹¹ J. Zhang, *On the Completeness of Orientation Rules for Causal Discovery in the Presence of Latent Confounders and Selection Bias* In *Artificial Intelligence*, 2008, vol. 172, no. 16–17, pp. 1873–1896

¹² S. Shimizu, P. O. Hoyer, A. Hyvärinen, A. Kerminen, *A Linear Non-Gaussian Acyclic Model for Causal Discovery* In *Journal of Machine Learning Research*, 2006, vol. 7, pp. 2003–2030

¹³ J. Peters, J. M. Mooij, D. Janzing, B. Schölkopf, *Causal Discovery with Continuous Additive Noise Models* In *Journal of Machine Learning Research*, 2014, vol. 15, pp. 2009–2053

中间节点不会反向改变 X_1 ；若机制是分叉 $X_1 \leftarrow X_2 \rightarrow X_3$ ，则会影响 X_1 。干预通过改变数据产生过程，而不是多收集同一种观测，区分了这两种解释。

完美干预 (perfect intervention) 替换目标节点的原机制，使其不再依赖原父节点，并保持非目标节点机制不变。设已知目标集合 $I \subseteq V$ ，对目标独立随机化，赋予外部规定的分布 q_i^I ，则

$$p^I(\mathbf{x}) = \prod_{i \in I} q_i^I(x_i) \prod_{j \notin I} p(x_j | \mathbf{x}_{\text{pa}_g(j)}). \quad (25.16)$$

图上这对应删除所有进入 I 的箭头，记干预图为 $g^{[I]}$ ；空目标 $I = \emptyset$ 对应观测环境。固定某个取值的干预可作退化版本，但用条件独立刻画等价类时，通常使用具有足够支持的随机化干预或覆盖所需取值的实验，避免固定变量造成退化。

设 $\mathcal{I}$ 是已知干预目标集合组成的族。它是**保守的** (conservative)，若每个节点都至少在一个环境中未被干预；只要包含观测环境就满足这一条件。**干预 Markov 等价类** (interventional Markov equivalence class, I-MEC) 是在给定 $\mathcal{I}$ 及完美干预约定下，允许相同多环境分布族的有向图集合。这里多环境分布要求共享非目标机制，不是任意独立挑选各环境的分布。

在保守目标族及相应正性设定下，两个有向图干预等价，当且仅当它们观测 Markov 等价，且对每个 $I \in \mathcal{I}$ ，删去目标入边后的两个干预图有相同骨架。等价地，也可要求观测图的骨架与 v -结构相同，并比较各干预图的 Markov 等价关系。**干预本质图** (interventional essential graph) 把 I-MEC 中所有有向图共同的方向画为有向边，其余画为无向边。I-MEC 细分观测 MEC，但目标选择不充分时仍可能含多张图¹⁴。

沿用二值例子，给三种观测等价图分别配置能够复原同一张表的局部条件分布。在 $\text{do}(X_2 = 1)$ 下，正向链预测 $(p(X_1 = 1), p(X_3 = 1)) = (0.5, 0.8)$ ，分叉预测 $(0.9, 0.8)$ ，反向链预测 $(0.9, 0.5)$ 。三个答案不同，而在观测条件 $X_2 = 1$ 下它们都给出 $(0.9, 0.8)$ 。图 25.3 显示，在观测环境之外，对 X_2 进行覆盖两种取值的完美干预可以区分这三种结构；这是总体层面的识别，不是有限样本下看到一个频率差就必然定向正确。

贪心干预等价搜索 (greedy interventional equivalence search, GIES) 在干预本质图空间中搜索，结合前向、后向以及转向操作比较 I-MEC。每条样本必须带有目标标签 I_r 。若目标随机化分布已知或不依赖候选图，去掉相同常数后的机制对数似然为

$$\ell(\mathcal{G}, \theta) = \sum_{r=1}^n \sum_{j \notin I_r} \log p_{\theta_j}(x_{r,j} | \mathbf{x}_{r,\text{pa}(j)}).$$

被干预节点的记录不用于拟合该节点的原机制，但仍可用于其子节点的机

¹⁴ A. Hauser, P. Bühlmann, *Characterization and Greedy Learning of Interventional Markov Equivalence Classes of Directed Acyclic Graphs* In Journal of Machine Learning Research, 2012, vol. 13, pp. 2409–2464




图 25.3 同一观测 MEC 在干预 X_2 后产生不同预测。蓝、黄、红三条横带分别对应正向链、分叉和反向链，右侧概率框用同色箭头与结构逐行映射；实线为干预后的保留边，虚线为被切断的入边。在该三节点例子及给定假设下，这些预测足以区分三个方向。

制拟合。适用于干预数据的惩罚评分还需考虑各机制可用的样本量，不能把不同环境全部当作同分布观测直接套普通评分。GIES 利用这些得分在 I-MEC 之间移动，目标是联合利用观测与干预信息；其名称本身不提供无条件的全局最优或因果恢复保证。

若干预目标未知，环境标签只表明机制发生了某种改变，还需联合推断目标，并限定哪些机制可变、变化是否足够可检测、非目标机制是否保持不变；若是软干预，只改变部分机制参数而不切断全部父依赖，上述删边图与 I-MEC 定义就不再原样适用。干预不完全、执行不遵从、同时影响多个未知节点，或者非目标机制随环境漂移，也会改变识别条件。即使目标已知，未经建模的潜在混杂仍会使普通充分有向图版本的 GIES 不适用。

主动实验设计（active experimental design）是在预算允许的目标中，选择预计最能区分当前候选结构的下一次干预。例如三节点链中，重复被动观测不能决定可逆方向，而干预中间节点可使三个候选给出不同预测。具体设计可按预期后验熵下降、待定端点减少或目标科学问题的区分度来选择，并把成本和可执行性加入约束。计划中的“信息增益”仍基于当前模型及机制不变假设，不应把它当作尚未实施实验的结果。

表 25.2 归纳各路线的假设与输出。它不是互斥的算法分类：ANM 可同时使用回归、独立性检验和评分，连续优化也可求解带特定函数假设的目标。决定识别能力的是模型与数据提供了什么信息，而不是代码是否使用梯度。

路线	关键条件与信息	理想识别对象及限制
PC	无环、因果充分、Markov 且忠实；准确独立性信息	CPDAG；不决定类内可逆方向
GES	相应充分有向图模型；评分等价、可分解、局部一致	大样本下 CPDAG；不是一般贪心搜索的保证
FCI	允许潜在混杂；相应 Markov 性、忠实性及选择机制假设	PAG；不是潜变量完整图
LINGAM	线性无环、独立非高斯扰动、无潜在混杂	模型条件下单个有向图；依赖分布形状
ANM	独立加性噪声、无混杂及特定可识别性条件	满足条件时单个有向图；存在双向可表示例外
GIES	已知目标的完美干预、无混杂、机制不变、相应评分	搜索 I-MEC；并非一般全局最优保证

表 25.2 识别假设决定可追求的输出。表中的理想对象以总体条件成立为前提，实际算法还受有限样本、模型拟合和搜索误差影响。

25.4.4 因果发现的边界

结构不确定性至少有三种不同来源。有限样本误差使检验和评分偏离总体结论，更多同类数据有机会减少它；模型假设错误，例如存在潜在混杂却使用因果充分算法，可能让更多数据更稳定地支持错误解释；总体不可识别则意味着多个结构对所有允许的数据都给出同样的分布，单纯增大样本量不能区分。诊断结果时，应明确当前顾虑属于哪一类，才能决定补样本、改模型还是增加实验信息。

观测等价不是算法实现不够好，PAG 中的圆圈也不是必须消灭的绘图缺陷。领域知识可以排除部分结构，但这些方向应标记为先验约束的贡献；函数形式能够增加可识别性，但必须接受检验这些形式假设的责任。没有独立依据时，一张稀疏、有向且重复出现的图，仍不足以证明其为真实因果结构。

本节只回答结构发现的目标及识别边界。某个干预效应是否可由现有数据计算，是因果效应识别的问题；do 演算及反事实推断还有各自的定义和条件。恢复部分结构并不等于已解决所有效应查询，不能把这里的结构结果直接当作任意政策或个体反事实结论。

25.5 算法分析

把数据、假设、评分和搜索区分以后，才有可能准确评价一个结构学习结果。“一致”“最优”“稳定”分别回答不同问题，彼此不能替代。

25.5.1 统计一致性与有限样本误差

设 $\mathcal{C}^*$ 表示在声明的信息下可识别的目标，例如一个 CPDAG 而不是任意真实有向图。**结构一致性** (structural consistency) 通常要求 $\mathbb{P}(\hat{\mathcal{C}}_n = \mathcal{C}^*) \rightarrow 1$ 。目标写成什么，结论就只能达到哪里。树分布不成立时，Chow-Liu 可趋向最佳树近似；这不等于恢复生成分布的真实图。图 Lasso 的参数误差趋零也不自动意味着零元素模式完全正确，还需要非零边与零之间具有足够间隔。

PC 的一致性取决于会执行的条件独立判断能同时趋于正确，而不是每个检验看起来有合理的 p 值。若需考虑的检验集合大小为 M ，并且每项错误概率都至多为 δ ，则联合界给出至少一次错误的概率不超过 $M\delta$ ，不要求检验独立。对自适应选取的检验，必须控制全部可能被选中的相关集合，不能只事后数实际执行了多少次。固定显著性水平一般也不足以保证整体选图错误概率随 n 消失，需要相应阈值序列和功效条件。

弱边是统计困难的直接来源。高斯检验中，非零偏相关若小于估计波动尺度，就难以可靠保留；离散检验中，条件集扩大使每个配置可用的样本减少。高维稀疏性可以限制必要条件集大小，但仍需控制最大度、变量状态数、协方差条件数或最小信号等量，不能仅以“图稀疏”概括全部一致性假设。

BIC 的一致性解释也有条件。在固定维、正确设定及常规正则条件下，遗漏真实依赖通常造成随 n 线性增长的似然损失，而不必要的参数所获得的随机拟合收益通常仅为有界概率量级， $\log n$ 惩罚因而有机会区分二者。该论证针对候选模型比较；搜索器若没有到达正确模型，评分的一致性不会自动挽救搜索结果。潜变量奇异性或维数随样本增长时，不能直接照搬

这一理由。

Chow-Liu 的有限样本稳定性可以用一个更具体的间隔解释。设 $d \geq 3$ 且总体最大权生成树唯一，对每条不在树中的边 e ，考察其连接路径上的各树边 f ，定义

$$\Delta = \min_{e \notin E_{T^*}} \min_{f \in \text{path}_{T^*}(e)} \{I_f - I_e\}.$$

当 $\Delta > 0$ ，且所有经验互信息误差都小于 $\Delta/2$ 时，各非树边与路径边的关键次序保持不变，最大权生成树不变。三节点例子中这个间隔约为 0.072654，由两条较小互信息之差得到。若间隔为零，树结构可能不唯一，即使分布预测相近，具体边的选择也可能随样本扰动改变。

25.5.2 计算复杂度与可扩展性

不同算法的主要成本并不相同。PC 的成本由条件集枚举和每次检验决定；若整个搜索过程中候选邻域大小被 q 控制，一个粗略检验数上界为 $O(d^2 2^q)$ ，再乘单次检验代价。这个 q 不是无条件等于真实最大度：有限样本误保留的边也可能扩大邻域。FCI 需搜索更丰富的分离集合，通常比同规模 PC 承担更多工作。

完整离散有向图的局部评分可缓存，但每个节点仍可能有指数多候选父集。动态规划在预计算好最佳父集表后，常见的子集递推为 $O(d2^d)$ 时间量级，局部表的准备与存储本身也很昂贵；整数规划的分支搜索同样可能指数增长。局部有向图搜索单轮可以考察 $O(d^2)$ 个边操作，但轮数、无环检查和局部拟合代价仍需另外计算，不能把单轮操作数当作总复杂度。

若各离散变量状态数有界，Chow-Liu 可用 $O(nd^2)$ 时间累积成对计数，再在稠密完全图上用 $O(d^2)$ 时间量级的 Prim 算法求树，或排序边后用 $O(d^2 \log d)$ 的 Kruskal 算法。完成模型后，树上的一次有限状态边缘推断随节点数线性增长。它同时简化学习与推断，但这个优势以树族的表达限制为代价。

稠密 NOTEARS 实现中，计算 $\mathbf{Y}\mathbf{W}$ 约需 $O(nd^2)$ 运算，矩阵指数通常涉及 $O(d^3)$ 量级的稠密线性代数；还要乘以内部优化和惩罚更新的轮数。图 Lasso 也有矩阵更新成本，但其目标凸；稀疏邻域回归容易按节点并行，却需处理估计的一致性。高阶离散模型的瓶颈可能不是枚举边，而是在每次评分时计算配分函数。最大父集、候选筛选和限制作用域等手段，应同时报告它们节省了什么计算、排除了哪些结构。

25.5.3 结构评价与稳定性

有已知生成图的仿真中，可以分别评价骨架和方向。骨架精确率为正确预测边数除以预测边数，召回率为正确预测边数除以真实边数；分母为零时应预先规定记法。方向评价应明确是只在骨架预测正确的边上计算，还是

把漏边也纳入分母。若真实可识别对象只是 CPDAG，就不应把算法没有猜中某个代表有向图的可逆方向算作错误，也不应因算法任意猜对该方向就奖励其识别能力。

结构 Hamming 距离 (structural Hamming distance, SHD) 统计把估计图变为目标图所需的边编辑数。常用有向图约定把一次加边、删边或反向各计 1；有些实现把反向计为一次删除加一次添加，因此比较结果必须注明口径。对 CPDAG，应先把真有向图转为相应等价类表示，再分别比较邻接、被迫方向和未定向状态；对 PAG，还需评价圆圈、尾端和箭头端，不能直接套二值邻接矩阵的距离。

真实数据中往往没有真图可比。**自助重采样** (bootstrap) 可以从 n 条独立记录中有放回抽取 n 条，重复拟合 B 次，并记录某条边的出现频率

$$\hat{\pi}_{i,j} = \frac{1}{B} \sum_{b=1}^B \mathbf{1}\{i,j\} \text{ 在第 } b \text{ 次结果中相邻} \}.$$

方向频率应另行统计，并声明分母是所有重复，还是只包括该边出现的重复。CPDAG 中未定向的结果不能被强制补全后计成方向支持；每轮的调参和筛选是否重做，也会影响稳定性含义。多环境数据应在环境内重采样，相关序列则需适当的块重采样，不能把不独立的记录当作独立单位。

重采样频率衡量流程对数据扰动的敏感性，不是结构后验概率，也不是因果真实性概率。一个错误的先验限制或错误的分布假设可能在每轮都产生同一个错误结果。还应比较不同正则强度、独立性检验设置和合理模型假设下的变化，并用独立验证数据评价预测表现；预测好本身仍不能证明方向正确。

领域知识可以直接进入候选空间。禁止边使其候选局部得分不可用，必选边限制允许父集，时间顺序排除逆时间箭头；进入搜索前还要检查这些约束是否彼此矛盾或已经形成有向环。在等价类输出中，应区分数据确定的方向和背景知识补充的方向，并相对于加入相同知识后的识别对象评价。这样报告的结构才同时说明“看到了什么”和“事先假定了什么”。

25.6 本章小结

从记录中学习图，不是把相关系数变成连线这么简单。条件独立约束回答哪些联系可以被给定变量隔断，评分衡量候选分布的拟合和复杂度，搜索决定怎样遍历合法结构。三者可以组合，却承担不同责任。Chow-Liu 之所以能够精确求解，是因为树的最佳似然分解为互信息边权之和；一般有向图和高阶无向模型没有同样的简化。

结构输出必须与信息相称。同一张计数表可以支持一个无向链、一个有向图等价类，也可以给多个图赋予后验权重，但不能仅凭观测频率决定链

的因果方向。缺失数据需要推断未观测统计量，潜变量可能把稀疏条件图变成稠密边缘图；这些变化不仅增加计算量，也改变可识别的对象。因果发现只有在明确的机制、混杂、忠实性或函数形式假设下，才可把统计证据解释为 CPDAG、PAG 或更细的干预等价类。

因此，一个可信的结构学习结论应同时给出候选模型、数据和干预条件、评分或检验、搜索限制，以及输出中的不确定性。样本更多、优化更充分和模型假设更合适，分别解决不同问题；观测层面的不可识别仍可能需要新的实验信息。回到章首，数据能够帮助选择解释依赖的图，但箭头是否代表故障传播，必须由相应的识别假设和干预证据承担，而不能由绘图代替论证。

后续模型章节将改变提问方式：给定分类、潜在分组或状态估计任务，哪些结构假设能同时满足表达与计算需要？第 26 章从静态有向模型开始，把前面的分解、推断和学习方法用于具体模型。采用一种模型结构，仍不等于其潜变量已获得唯一的物理解释。

静态有向模型

同一台设备的两个传感器经常同时给出较高读数。描述这种相关性至少有两种办法：直接用第一个读数预测第二个读数，或假设二者受到某个未观测工作状态的共同影响。两种办法都能定义观测数据的联合分布，却把计算放在不同位置。前者需要拟合条件分布；后者还需要回答工作状态是什么，以及怎样把这个状态从联合分布中消去。一个模型能否解释相关性、能否评价似然、能否补全缺失观测，并不是同一个问题。

第 17 章已经建立有向分解的概率语义，前面的推断与学习章节也给出了处理求和、积分和未知参数的通用方法。本章把这些工具落实到静态模型中。“静态”表示这里不假设变量沿真实时间演化，不表示变量之间没有依赖。记一条记录的观测为 $\mathbf{x} \in \mathbb{R}^d$ 或相应的离散取值向量，训练集包含 n 条记录 $\mathbf{x}_1, \dots, \mathbf{x}_n$ ，全部待估计参数合记为 θ 。类别标签存在时另记为 Y ，此时完整图还包含类别节点。

本章围绕“怎样用有向结构定义并使用观测分布”展开。直接模型从观测之间建立条件分布；潜变量模型则先定义更大的联合分布，再求和或积分得到观测分布。潜变量可以离散，也可以连续；它们还可以在多个组之间共享，或允许同一组同时使用多个成分。取值类型和共享方式描述不同的属性，不能排成互斥类别。模型比较将回到这两组属性，说明它们如何影响推断、参数估计和结果解释。

26.1 直接模型

当一条完整记录给出了图中所有随机变量的取值时，有向分解可以直接评价这条记录的概率。只要每个局部条件分布已归一化且可计算，联合分布就不需要另求全局归一化常数。不过，完整记录的概率容易计算，不保证任意缺失模式下的边缘概率同样容易计算。下面的两个模型族分别通过限制父集、共享条件分布的计算来控制规模。

26.1.1 朴素贝叶斯与树增强模型

若训练记录既有传感器读数又有设备类别，可以先按类别描述读数的分布，再反推新设备的类别。**朴素贝叶斯** (naive Bayes, NB) 把类别作为所有属性的共同父节点：给定类别后，各属性分别生成，不再相互提供信息。设 Y 有 K 个类别，其概率为 $\pi_k = p(Y = k)$ ，则

$$p(y, \mathbf{x}) = \pi_y \prod_{i=1}^d p(x_i | y), \quad p(y | \mathbf{x}) = \frac{\pi_y \prod_i p(x_i | y)}{\sum_{k=1}^K \pi_k \prod_i p(x_i | k)}. \quad (26.1)$$

这里的条件独立是给定类别后的共同独立，而不只是属性之间两两独立。把 Y 消去以后，各属性通常仍然相关。训练时类别与属性均已观测，所以最大似然估计分解为类别比例与每类内的局部估计；预测时类别未知，但只需枚举 K 个类别。变量在当前查询中是否已知取决于给定的证据；预测时尚未知晓的标签不因此成为模型主动引入的潜变量，也不等于本应记录却漏记的缺失值。

对二值属性，可用 $a_{i,k} = p(X_i = 1 | Y = k)$ 参数化。若训练集中类别 k 的样本数为 $n_k > 0$ ，其中第 i 个属性取 1 的次数为 $n_{i,k}^+$ ，则 $\hat{\pi}_k = n_k/n$ 、 $\hat{a}_{i,k} = n_{i,k}^+/n_k$ 。零计数可能把测试记录的整个乘积压成零；采用正的狄利克雷伪计数可以平滑条件表。未出现过的类别或父配置需要先验或额外约束，不能直接计算 $0/0$ 。连续属性也可使用类内高斯密度等局部模型，但仍需明确其分布假设。

以二分类为例，若所有 $a_{i,k}$ 与类别先验都严格位于 $(0, 1)$ ，对数后验比为

$$\begin{aligned} \log \frac{p(Y = 1 | \mathbf{x})}{p(Y = 0 | \mathbf{x})} &= b + \sum_{i=1}^d w_i x_i, \\ b &= \log \frac{\pi_1}{\pi_0} + \sum_i \log \frac{1 - a_{i,1}}{1 - a_{i,0}}, \\ w_i &= \log \frac{a_{i,1}(1 - a_{i,0})}{a_{i,0}(1 - a_{i,1})}. \end{aligned} \quad (26.2)$$

这个线性边界来自伯努利对数似然比，不是“所有朴素贝叶斯都线性”的结论。类间方差不同的高斯属性会产生平方项；一般类别属性则可以看成对类别指示特征的加性评分。生成式估计得到这些系数的方式，也不同于直接最小化分类损失。

示例 26.1 两个二值读数 为比较直接分解与潜变量解释，另设一个个人工传感器模型，不把它看作四节点报警模型的改名。 $Y = 1$ 表示

某种异常工作状态, X_1, X_2 是两个二值读数。设

$$p(Y = 1) = 0.1,$$

$$p(X_1 = 1 | Y = 1) = 0.8, \quad p(X_1 = 1 | Y = 0) = 0.1,$$

$$p(X_2 = 1 | Y = 1) = 0.7, \quad p(X_2 = 1 | Y = 0) = 0.2.$$

在给定 Y 时假设两个读数独立。观测到 $(X_1, X_2) = (1, 1)$ 后, 两类的未归一化概率分别为 $0.1 \times 0.8 \times 0.7 = 0.056$ 和 $0.9 \times 0.1 \times 0.2 = 0.018$, 所以

$$p(Y = 1 | 1, 1) = \frac{0.056}{0.074} = \frac{28}{37} \approx 0.7568.$$

边缘上 $p(X_1 = 1) = 0.17$ 、 $p(X_2 = 1) = 0.25$, 而 $p(1, 1) = 0.074$ 不等于 $0.17 \times 0.25 = 0.0425$ 。二者的协方差为 0.0315: 共同类别足以产生观测相关性。

条件独立假设失效时, 多个读数可能重复贡献同一份证据。在另一个极端情形中, 令 $X_2 = X_1$ 为完全相同的复制读数, 保留上例的类别先验与 X_1 分布。正确后验为 $0.08/(0.08 + 0.09) = 8/17$; 误当作两个独立属性后, 后验变成 $0.064/(0.064 + 0.009) = 64/73$ 。类别判断甚至会改变, 且预测置信度被明显放大。分类准确率较好也不能单独证明独立性假设或后验概率校准良好。

要保留容易学习的结构, 同时允许属性之间有一些类内相关性, 可以使用**树增强朴素贝叶斯** (tree-augmented naive Bayes, TAN): 类别仍指向所有属性, 属性之间再增加一棵树。选一个属性 r 为树根, 把树边从根向外定向; 非根属性 i 的属性父节点记为 $t(i)$, 则

$$p(y, \mathbf{x}) = p(y)p(x_r | y) \prod_{i \neq r} p(x_i | y, x_{t(i)}). \quad (26.3)$$

每个属性最多增加一个属性父节点。给定类别后, 图变成一棵有向树, 而不再是相互独立的节点。图 26.1 画出了这项变化; 树边表示允许利用类内依赖, 并不自动具有因果含义。




图 26.1 朴素贝叶斯与树增强模型。两图的类别 Y 均指向三个属性; 右图增加 $X_1 \rightarrow X_2 \rightarrow X_3$, 因此给定 Y 后仍保留树上的属性依赖。节点是否观测由训练或预测任务决定。

结构增加多少参数, 可以直接数条件表的自由度。设属性 i 有 r_i 种取值, NB 需要 $(K-1) + K \sum_i (r_i - 1)$ 个自由参数; 固定一棵 TAN 树后, 需要

$$(K-1) + K(r_r - 1) + K \sum_{i \neq r} r_{t(i)}(r_i - 1).$$

两个类别、三个二值属性时, 参数数目从 7 增加到 11。这远小于不受限制的完整联合表, 但每个新条件表需要更多样本支持。对完整记录, 两种模型的类别评分都只需 $O(Kd)$ 次局部查询; 二值 TAN 的对数评分可包含 $x_i x_{t(i)}$ 交互项, 因而不局限于 NB 的加性边界。

TAN 的树可以从完整离散训练数据中求得。用经验分布 $\hat{p}$ 定义条件互信息

$$\hat{I}(X_i; X_j | Y) = \sum_{y, x_i, x_j} \hat{p}(y, x_i, x_j) \log \frac{\hat{p}(x_i, x_j | y)}{\hat{p}(x_i | y) \hat{p}(x_j | y)}.$$

对正频数项计算此式, 零频数项按连续延拓取 0。把任意候选树的条件表取为最大似然估计, 平均训练对数似然就等于

$$-\hat{H}(Y) - \sum_i \hat{H}(X_i | Y) + \sum_{\{i, j\} \in E_T} \hat{I}(X_i; X_j | Y), \quad (26.4)$$

其中 $\hat{H}$ 为经验熵, E_T 为属性树的无向边集。等式来自每条树边上的恒等式 $H(X_i | Y, X_j) = H(X_i | Y) - I(X_i; X_j | Y)$; 根节点保留原来的条件熵, 其余节点各贡献一条边的互信息。前两项不依赖树, 因此用条件互信息作边权求最大生成树即可, 再任取根定向。无惩罚、观测完整、自由条件表是这个结论的前提; 加入结构惩罚或参数约束后不能直接照搬。

若所有 $r_i \leq r$, 朴素的成对计数需要 $O(nd^2)$ 次更新, 遍历条件表计算边权需要 $O(Kd^2r^2)$ 操作, 稠密图上的最大生成树可在 $O(d^2)$ 时间内得到。NB 无需搜索树, 计数只需 $O(nd)$ 次更新。TAN 用这项额外结构学习成本换取类内依赖, 却不能表示任意高阶相互作用; 稀疏数据下, 一条虚假的树边也会增加估计误差。TAN 的提出与具体算法见 Friedman 等人的工作, 树结构学习的一般推导可回看第 25 章¹。

26.1.2 自回归密度模型

如果目标是拟合观测分布, 而不是依赖某个已知类别来简化属性关系, 可以为每个变量保留全部前驱。选定顺序后, 将排在第 i 位之前的取值向量记为 $\mathbf{x}_{<i}$ 。自回归密度模型 (autoregressive density model) 逐个预测当前变量的条件分布, 再把这些条件分布相乘:

$$p_{\theta}(\mathbf{x}) = \prod_{i=1}^d p_{\theta}(x_i | \mathbf{x}_{<i}). \quad (26.5)$$

¹ N. Friedman, D. Geiger, M. Goldszmidt, *Bayesian Network Classifiers* In *Machine Learning*, 1997, vol. 29, no. 2-3, pp. 131–163

这里的顺序可以是表格字段顺序或图像像素的扫描顺序，不一定是真实时间； $\mathbf{x}_{<1}$ 为空，第一项就是边缘分布。

式 (26.5) 为何自动归一化？在离散情形，先对 x_d 求和，最后一个条件分布的和为 1；再对 x_{d-1} 求和，如此递推，最终剩下 $\sum_{x_1} p(x_1) = 1$ 。连续情形把求和改为积分，对非负、可测且对每个前缀归一化的条件密度，可由 Tonelli 定理交换积分顺序，得到同一结论。由给定联合分布反求条件分布时，零概率前缀上的条件分布可以任意补成归一化分布，不会改变原联合分布。这证明的是模型的归一化，不是它已经拟合真实数据。

链式法则本身对表达能力没有限制：任意给定联合分布都可以沿任意排列写成这种形式。限制来自局部参数化。若每个二值条件都用完整条件表，参数总数仍为 $1 + 2 + \dots + 2^{d-1} = 2^d - 1$ ；换成有限宽度的网络、有限感受野或简单高斯条件后，不同顺序就可能对应不同难度和不同近似误差。某个顺序使条件分布接近单峰，反向顺序的条件分布却可能多峰；小容量模型不会自动适应这种变化。

例 26.1 的两个读数也能直接自回归建模。把类别求和消去后，得到观测分布

$$\begin{array}{ccccc} (x_1, x_2) & (0, 0) & (0, 1) & (1, 0) & (1, 1) \\ p(x_1, x_2) & 0.654 & 0.176 & 0.096 & 0.074 \end{array}$$

相应的三个自回归参数为

$$\begin{aligned} p(X_1 = 1) &= 0.17, \\ p(X_2 = 1 | X_1 = 1) &= \frac{37}{85}, \\ p(X_2 = 1 | X_1 = 0) &= \frac{88}{415}. \end{aligned}$$

例如 $p(1, 1) = 0.17 \times 37/85 = 0.074$ 。这个直接分解完整保留了读数之间的相关性，但没有给出工作状态 Y 的含义与后验。观测分布相同，不等于模型对未观测机制作出了同样的解释。

为减少条件表的规模，**神经自回归分布估计器** (neural autoregressive distribution estimator, NADE) 在不同前缀之间共享神经网络参数。对二值观测，一个宽度为 h 的单隐藏层形式为

$$\mathbf{a}_i = \mathbf{c} + \sum_{j < i} \mathbf{W}_{:,j} x_j, \quad \mathbf{h}_i = \text{sigmoid}(\mathbf{a}_i), \quad (26.6)$$

$$p(X_i = 1 | \mathbf{x}_{<i}) = \text{sigmoid}(b_i + \mathbf{V}_{i,:} \mathbf{h}_i).$$

其中 $\mathbf{W} \in \mathbb{R}^{h \times d}$ 、 $\mathbf{V} \in \mathbb{R}^{d \times h}$ ， $\mathbf{c}$ 和 $\mathbf{b}$ 为偏置， $\text{sigmoid}(u) = (1 + \exp(-u))^{-1}$ 。递推 $\mathbf{a}_{i+1} = \mathbf{a}_i + \mathbf{W}_{:,i} x_i$ 只需 $O(h)$ 操作，整条记录的密度评价因此为 $O(dh)$ ，无需为每个前缀重做全部输入求和。这里的 $\mathbf{h}_i$ 是输入的确定性函数，不是需要积分的随机潜变量。NADE 的共享计算正是其可计算似然的重要来

源²。

前缀递推也可以改成一次带约束的前馈计算。**掩码自编码分布估计器** (masked autoencoder for distribution estimation, MADE) 把违反顺序的网络连接设为零, 使第 i 个输出只能读到 $\mathbf{x}_{<i}$ 。设输入 j 的次序号为 j , 隐藏单元 u 的次序号为 $m(u)$ 。输入到隐藏层只允许 $j \leq m(u)$ 的边, 隐藏层到输出 i 只允许 $m(u) < i$ 的边。深层网络的中间边要求次序号非递减, 输出边仍严格小于 i ; 于是任何输入到输出的路径都满足 $j < i$, 当前变量和未来变量无法泄漏到该条件分布中。

图 26.2 给出三个输入、两个隐藏单元的例子, 隐藏次序号为 1, 2。按“行是接收端、列是发送端”排列, 两个掩码是

$$\mathbf{M}_{\text{in}} = \begin{pmatrix} 1 & 0 & 0 \\ 1 & 1 & 0 \end{pmatrix}, \quad \mathbf{M}_{\text{out}} = \begin{pmatrix} 0 & 0 \\ 1 & 0 \\ 1 & 1 \end{pmatrix}.$$

它们的乘积为 $\begin{pmatrix} 0 & 0 & 0 \\ 1 & 0 & 0 \\ 2 & 1 & 0 \end{pmatrix}$, 严格下三角; 其中 2 表示两条合法计算路径, 不表示两倍概率。第一个输出只使用偏置, 第三个输入不参与任何条件参数的计算, 但它仍作为第三个条件分布的目标取值进入似然。普通自编码器可以直接复制当前输入, 因此普通重构误差并不自动成为归一化联合分布的负对数似然; MADE 需要上述路径约束³。

图像中的条件分布可以利用空间参数共享。**像素卷积自回归模型** (PixelCNN) 用带掩码的卷积预测各像素的条件分布: 按逐行顺序, 当前像素只读取上方以及同一行左侧的合法上下文。输入层的掩码排除当前目标; 后续隐藏层可以读取当前位置已经合法的隐藏表示, 但不能重新接入当前目标值。彩色图像还需约定同一像素内的通道顺序, 例如红、绿、蓝, 否则通道间也会泄漏目标。有限层数与卷积核形成有限感受野, 归一化并不保证网络利用了全部前驱。PixelCNN 与 PixelRNN 在原始论文中共同讨论, 本节所用的是卷积掩码这一依赖保证⁴。

模型输出的必须是一个分布, 而不只是预测均值。二值变量可输出伯努利概率; 有 r 种取值的变量可输出经 softmax 归一化的 r 个概率, 原始 PixelCNN 用这种方式建模每通道 256 个离散值。连续变量则可以输出 $\mu_i(\mathbf{x}_{<i})$ 与严格为正的尺度 $\sigma_i(\mathbf{x}_{<i})$, 得到条件高斯密度; 多峰条件可以输出有限高斯混合的权重、均值和尺度。这样的局部混合可以引入一个被显式求和的成分指示变量, 所以“使用混合参数化”与“联合似然难算”并不等价。离散概率质量不能直接同连续密度值比较; 将量化像素视为连续数据时, 还须明确量化区间的积分或去量化方案。

² H. Larochelle, I. Murray, *The Neural Autoregressive Distribution Estimator* In Proceedings of the Fourteenth International Conference on Artificial Intelligence and Statistics, 2011, pp. 29–37

³ M. Germain, K. Gregor, I. Murray, H. Larochelle, *MADE: Masked Autoencoder for Distribution Estimation* In Proceedings of the 32nd International Conference on Machine Learning, 2015, pp. 881–889

⁴ A. van den Oord, N. Kalchbrenner, K. Kavukcuoglu, *Pixel Recurrent Neural Networks* In Proceedings of the 33rd International Conference on Machine Learning, 2016, pp. 1747–1756




图 26.2 MADE 的合法计算路径。方框表示确定性隐藏计算，圆框表示输入或条件分布输出；输出 q_i 代表 $p(X_i = 1 | \mathbf{x}_{<i})$ 。下方 3×3 输入—输出掩码直接列出可读关系，蓝格中的 1 表示允许依赖；右侧以 $x_3 \rightarrow q_2$ 为非法后向连接反例。隐藏单元的次序号限定可读前缀，任何 q_i 都不能访问 x_i 或更后的输入。

对完整训练数据，负对数似然为

$$L(\theta) = - \sum_{j=1}^n \sum_{i=1}^d \log p_{\theta}(x_{j,i} | \mathbf{x}_{j,<i}). \quad (26.7)$$

所有真实前缀已知，MADE 和 PixelCNN 可以在固定网络深度的一次前向计算中同时产生各位置的条件参数，梯度按式 (26.7) 求和后更新共享权重。NADE 的传统实现利用前缀递推，共享参数也不等于每个条件可以独立训练。训练时应防止额外的跨位置操作破坏掩码，例如未经约束地汇总全部输入后再广播给所有输出。

生成新记录时，未来前缀还不存在。必须先采样 x_1 ，再用其结果采样 x_2 ，依此进行祖先采样。对具有完整顺序依赖的标量自回归模型，需要 d 轮相继决策；不同样本可以批量生成，但同一样本内部通常不能一次得到所有随机取值。缓存可以减少重复运算，不能消除模型规定的数据依赖。NB 的属性在给定类别后反而可以并行生成，TAN 也可以按树层并行，因此“有向”本身不是逐变量串行的充分理由。

直接分解的优势是完整似然可算、采样路径明确，但它没有解决所有推断问题。若仅观测一个前缀，剩余变量可以按原顺序生成；若第一维缺失而许多后续维已知，计算该缺失量的条件分布往往需要对一批变量求和

或积分。密度评价、祖先生成和任意条件补全的计算难度必须分别判断。第 29 章比较神经参数化生成模型时，将以这里的自回归模型作为直接似然路线的参照。

26.2 潜变量模型

观测之间的条件分布可以准确预测，却未必提供适合聚类、压缩或组间共享的表示。如果要用一个不可直接观测的状态解释多项观测，就需要把这个状态纳入概率模型。沿用第 24.1 节的约定，**潜变量** (latent variable) 是模型为了表达未观测状态而主动引入的随机量，不是本应记录却未取得的数据值；学习和预测需要处理对它的不确定性。记其取值为 $\mathbf{z}$ ，则观测分布为

$$p_{\theta}(\mathbf{x}) = \begin{cases} \sum_{\mathbf{z}} p_{\theta}(\mathbf{z}) p_{\theta}(\mathbf{x} | \mathbf{z}), & \text{离散潜变量,} \\ \int p_{\theta}(\mathbf{z}) p_{\theta}(\mathbf{x} | \mathbf{z}) d\mathbf{z}, & \text{连续潜变量.} \end{cases} \quad (26.8)$$

先验与条件分布归一化就保证观测分布归一化，但求和或积分是否能高效计算，需要逐个模型检查。潜变量也不是因果机制的自动证明；仅凭观测似然，常会存在多种等价解释。

26.2.1 离散潜变量与有限混合

一个设备总体可能包含几种不同工作状态，而训练数据只记录了读数。**有限混合模型** (finite mixture model) 先抽取一个离散成分，再按该成分的分分布生成整条记录。设 $Z \in \{1, \dots, K\}$ 、 $\pi_k \geq 0$ 且 $\sum_k \pi_k = 1$ ，成分参数为 θ_k ，则

$$p(Z = k, \mathbf{x}) = \pi_k p(\mathbf{x} | \theta_k), \quad p(\mathbf{x}) = \sum_{k=1}^K \pi_k p(\mathbf{x} | \theta_k). \quad (26.9)$$

混合权重控制成分出现的频率，成分分布控制成分内部的变化。给定共享参数，各记录独立同分布，每条记录拥有自己的 Z_j ，而权重和成分参数在记录之间共享。例 26.1 中，若类别不再被记录，原来的两个类内伯努利乘积分布就构成一个两成分混合；其观测概率仍是同一张二元概率表。

潜变量为什么能解释相关性，可以用全协方差公式看清。对任意两个有限二阶矩的属性，

$$\text{Cov}(X_1, X_2) = \mathbb{E}[\text{Cov}(X_1, X_2 | Z)] + \text{Cov}(\mathbb{E}[X_1 | Z], \mathbb{E}[X_2 | Z]).$$

即使成分内部条件独立使第一项为零，不同成分的均值一起升降也会使第二项非零。对前面的两个二值读数，该项为 $0.1 \times 0.9 \times (0.8 - 0.1) \times (0.7 - 0.2) = 0.0315$ ，与直接计算一致。若成分本身已有相关性，第一项也应保留，不能把所有混合模型都画成“给定 Z 后属性独立”的图。

对连续读数，**高斯混合模型**（Gaussian mixture model, GMM）令 $p(\mathbf{x} | Z = k) = \mathcal{N}(\mathbf{x}; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)$ ，其中 $\boldsymbol{\Sigma}_k$ 正定。全协方差允许成分沿任意方向伸展，每个成分需要 $d(d+1)/2$ 个协方差参数；对角协方差只需 d 个参数，但强加给定成分后的属性独立；球形协方差 $\sigma_k^2 \mathbf{I}$ 只需一个尺度。所有成分共享一个协方差又是另一种约束，它减少参数，却限制不同成分拥有不同形状。混合以后即使每个成分是对角高斯，观测总体也不必具有对角协方差。

给定参数，对单条记录的后验只需比较 K 项。**责任度**（responsibility）就是每个成分对这条记录的后验概率，而不是硬聚类标签：

$$r_{j,k}^{(t)} = \frac{\pi_k^{(t)} \mathcal{N}(\mathbf{x}_j; \boldsymbol{\mu}_k^{(t)}, \boldsymbol{\Sigma}_k^{(t)})}{\sum_{\ell=1}^K \pi_{\ell}^{(t)} \mathcal{N}(\mathbf{x}_j; \boldsymbol{\mu}_{\ell}^{(t)}, \boldsymbol{\Sigma}_{\ell}^{(t)})}. \quad (26.10)$$

当 $\mathbf{x}_j = (1, 1)$ 来自前面的二值混合时，异常成分的责任度仍为 $28/37$ ；区别在于现在没有训练标签可以直接用于估计局部表。未知成分使参数学习与后验推断相互依赖。

第 24 章的 EM 方法在这里有明确的两步。E 步用式 (26.10) 计算旧参数下的责任度；M 步把它当作固定权重，最大化期望完全数据对数似然

$$Q = \sum_{j,k} r_{j,k}^{(t)} \left(\log \pi_k - \frac{1}{2} \log |\boldsymbol{\Sigma}_k| \right) - \frac{1}{2} \sum_{j,k} r_{j,k}^{(t)} (\mathbf{x}_j - \boldsymbol{\mu}_k)^{\top} \boldsymbol{\Sigma}_k^{-1} (\mathbf{x}_j - \boldsymbol{\mu}_k) + \text{常数}.$$

在 $\sum_k \pi_k = 1$ 约束下对权重求驻点，得到加权样本比例；对均值求导，得到加权均值；将均值代回后，对协方差求驻点，得到加权残差二阶矩。写 $N_k^{(t)} = \sum_j r_{j,k}^{(t)}$ ，在 $N_k^{(t)} > 0$ 且更新后的协方差正定时，

$$\begin{aligned} \pi_k^{(t+1)} &= \frac{N_k^{(t)}}{n}, \\ \boldsymbol{\mu}_k^{(t+1)} &= \frac{\sum_j r_{j,k}^{(t)} \mathbf{x}_j}{N_k^{(t)}}, \\ \boldsymbol{\Sigma}_k^{(t+1)} &= \frac{1}{N_k^{(t)}} \sum_j r_{j,k}^{(t)} (\mathbf{x}_j - \boldsymbol{\mu}_k^{(t+1)}) (\mathbf{x}_j - \boldsymbol{\mu}_k^{(t+1)})^{\top}. \end{aligned} \quad (26.11)$$

对角模型保留最后一式的对角元素；球形模型取其迹除以 d 。这些是相应协方差约束下的极大化结果，而不是把全协方差训练完成后随意删去非对角项。

示例 26.2 一轮可复核的高斯混合 EM 设一维人工数据为 $x_1 = -1, x_2 = 1$ ，两个成分初始权重均为 $1/2$ ，均值分别为 $-1, 1$ ，方差

均为 1。对 x_1 ，两个加权密度的比为 $1 : \exp(-2)$ ，因此

$$\mathbf{R}^{(0)} = \begin{pmatrix} a & 1-a \\ 1-a & a \end{pmatrix}, \quad a = \frac{1}{1 + \exp(-2)} \approx 0.880797.$$

每个成分的有效样本数为 1，新权重不变，新均值为 $\mu_1^{(1)} = 1 - 2a \approx -0.761594$ 和 $\mu_2^{(1)} = 2a - 1$ 。由于两个样本的平方都等于 1，两个加权二阶矩也都为 1，故

$$(\sigma_1^2)^{(1)} = (\sigma_2^2)^{(1)} = 1 - (2a - 1)^2 \approx 0.419974.$$

E 步没有把点完全交给某个成分，所以均值先向中间收缩；M 步随后按新的均值重新估计方差。这是一轮计算，不是全局收敛或良好泛化的证据。

对全协方差 GMM，每轮可先为 K 个协方差做分解，成本 $O(Kd^3)$ ；随后 nK 个二次型及协方差统计通常需要 $O(nKd^2)$ 操作。对角模型可降为 $O(nKd)$ 。只要成分密度可算，有限混合的观测似然和固定参数下的成分后验均可精确求得；难点主要在于非凸参数优化与成分选择，不是这个 K 项求和本身。实际计算责任度宜先计算对数得分，再减去最大值并做归一化，避免高维小密度相乘下溢。

无约束高斯混合的最大似然估计可能没有有限最优解。让一个成分的均值恰好落在某个训练点上，并令其协方差趋于零，该点的密度可以趋于无穷；其他成分仍可覆盖剩余点。上例的数据尤其少，继续迭代并不是解决这种退化的办法。协方差特征值下界、适当的先验或受约束估计可以排除相应退化路径，但会改变优化问题；手工重置成分也不继承原 EM 的单调性保证。初始化时可以用分散的样本或聚类中心，并比较多个起点；若 N_k 近零，需要按事先约定处理空成分，而不能让数值除法自行决定模型。模型选择还应考察留出似然与具体用途，不能只因训练似然增加就增加成分数。

另一种非唯一性不会改变预测。交换任意两个成分的权重、均值和协方差，式 (26.9) 完全不变，这称为**标签交换** (label switching)：成分编号只是命名，数据不会自动指定“第一类”的物理含义。它不同于两次优化找到不同局部极值。满足适当条件时，某些有限混合族可以在置换之外识别成分，但不能把这种性质推广到所有混合。例如前面的两成分、两个二值属性模型有 5 个自由参数，观测联合表只有 3 个自由度，通常还存在置换之外的非唯一分解。预测分布可以确定，而其潜在解释仍不唯一；对称后验下直接平均不同编号的成分参数，也可能毁掉有意义的预测摘要。混合模型的概率解释与估计细节可参看 Murphy 的教材⁵。

⁵ K. P. Murphy, *Machine Learning: A Probabilistic Perspective*, MIT Press, 2012

26.2.2 线性高斯潜变量模型

工作状态未必只有几个类别。温度负载、机械振动强度等因素可能连续变化，并同时影响多个传感器。可以用 $q < d$ 个连续潜在坐标解释这种共同变化，再为各观测保留独有噪声。**因子分析** (factor analysis, FA) 采用如下线性高斯模型：

$$\begin{aligned} \mathbf{Z} &\sim \mathcal{N}(\mathbf{0}, \mathbf{I}_q), \\ \mathbf{X} &= \boldsymbol{\mu} + \mathbf{W}\mathbf{Z} + \boldsymbol{\varepsilon}, \\ \boldsymbol{\varepsilon} &\sim \mathcal{N}(\mathbf{0}, \boldsymbol{\Psi}), \quad \boldsymbol{\Psi} = \text{diag}(\psi_1, \dots, \psi_d), \quad \psi_i > 0. \end{aligned} \quad (26.12)$$

这里 $\mathbf{Z}$ 与 $\boldsymbol{\varepsilon}$ 独立， $\boldsymbol{\mu} \in \mathbb{R}^d$ 为观测均值， $\mathbf{W} \in \mathbb{R}^{d \times q}$ 为载荷矩阵； $\mathbf{W}$ 的每一列描述一个潜在坐标同时改变哪些观测。给定全部潜在坐标后，观测之间因对角噪声而独立；不同潜在坐标的贡献则在线性均值中相加。

高斯向量的线性变换仍为高斯，且独立随机量的协方差相加，因此消去潜变量得到

$$\mathbf{X} \sim \mathcal{N}(\boldsymbol{\mu}, \mathbf{C}), \quad \mathbf{C} = \mathbf{W}\mathbf{W}^\top + \boldsymbol{\Psi}. \quad (26.13)$$

这把总协方差拆成秩至多为 q 的共同变化和各传感器自己的噪声。若允许 $\boldsymbol{\Psi}$ 完全自由，观测协方差就可能由噪声解释，共同因子与噪声之间的分工会进一步不确定。对角假设不仅减少计算，也规定了模型如何解释相关性。

当所有观测方向的残余噪声大小相同，即 $\boldsymbol{\Psi} = \sigma^2 \mathbf{I}_d$ 时，就得到**概率主成分分析** (probabilistic principal component analysis, PPCA)。FA 允许某个传感器比另一个更嘈杂，PPCA 则假设在当前坐标单位下各方向噪声相同。改变特征单位会改变这项假设，所以输入的缩放不是无关紧要的预处理。两者都能给出降维表示，但概率解释还要求估计噪声并量化潜在坐标的不确定性。

潜变量后验可以由平方配方直接得到。记 $\mathbf{y} = \mathbf{x} - \boldsymbol{\mu}$ 和 $\mathbf{M} = \mathbf{I}_q + \mathbf{W}^\top \boldsymbol{\Psi}^{-1} \mathbf{W}$ ，将先验与条件密度相乘，只保留与 $\mathbf{z}$ 有关的项：

$$\begin{aligned} -2 \log p(\mathbf{z} | \mathbf{x}) &= \mathbf{z}^\top \mathbf{z} + (\mathbf{y} - \mathbf{W}\mathbf{z})^\top \boldsymbol{\Psi}^{-1} (\mathbf{y} - \mathbf{W}\mathbf{z}) + \text{常数} \\ &= \mathbf{z}^\top \mathbf{M} \mathbf{z} - 2\mathbf{z}^\top \mathbf{W}^\top \boldsymbol{\Psi}^{-1} \mathbf{y} + \text{常数}. \end{aligned}$$

$\mathbf{M}$ 因 $\boldsymbol{\Psi}$ 正定而正定。将上式写为 $(\mathbf{z} - \mathbf{m})^\top \mathbf{M} (\mathbf{z} - \mathbf{m}) + \text{常数}$ ，即可读出

$$\begin{aligned} p(\mathbf{z} | \mathbf{x}) &= \mathcal{N}(\mathbf{z}; \mathbf{m}, \mathbf{S}), \\ \mathbf{S} &= \mathbf{M}^{-1}, \quad \mathbf{m} = \mathbf{S} \mathbf{W}^\top \boldsymbol{\Psi}^{-1} (\mathbf{x} - \boldsymbol{\mu}). \end{aligned} \quad (26.14)$$

这同时给出后验均值和协方差。 $\boldsymbol{\Psi}^{-1}$ 使噪声较小的观测贡献更多精度；先验贡献单位精度，使弱观测下的潜在坐标向零收缩。对完整观测和固定参数，后验协方差不随观测数值改变；观测数值只改变后验均值。

对独立同分布的无缺失观测, FA 和 PPCA 的均值最大似然估计均为样本均值, 可以先令 $\mathbf{y}_j = \mathbf{x}_j - \bar{\mathbf{x}}$ 。给定旧载荷和噪声, 用式 (26.14) 计算 $\mathbf{m}_j$ 、 $\mathbf{S}$, 并记 $\mathbf{T}_j = \mathbf{S} + \mathbf{m}_j \mathbf{m}_j^\top = \mathbb{E}[\mathbf{Z}_j \mathbf{Z}_j^\top | \mathbf{x}_j]$ 。M 步最小化期望加权重构误差; 对 $\mathbf{W}$ 求导, 得到矩阵正规方程

$$\mathbf{W}^{(t+1)} \sum_j \mathbf{T}_j = \sum_j \mathbf{y}_j \mathbf{m}_j^\top.$$

右乘 $(\sum_j \mathbf{T}_j)^{-1}$ 就得到新载荷。由于每个 $\mathbf{T}_j$ 包含正定的 $\mathbf{S}$, 在正噪声、有限参数的当前迭代中该逆存在; 实现时宜解线性方程而不显式求逆。

噪声更新需要潜变量的不确定性, 不能只拿 $\mathbf{m}_j$ 当作无误差的真实坐标。写 $\mathbf{W}_+ = \mathbf{W}^{(t+1)}$, 期望残差协方差为

$$\begin{aligned} \mathbf{R} = \frac{1}{n} \sum_j [(\mathbf{y}_j - \mathbf{W}_+ \mathbf{m}_j)(\mathbf{y}_j - \mathbf{W}_+ \mathbf{m}_j)^\top \\ + \mathbf{W}_+ \mathbf{S} \mathbf{W}_+^\top]. \end{aligned} \quad (26.15)$$

FA 令 $\psi_i^{(t+1)} = \mathbf{R}_{i,i}$, PPCA 令 $(\sigma^2)^{(t+1)} = \text{tr}(\mathbf{R})/d$ 。第二项恰好补上潜变量后验方差造成的残差; 漏掉它会把噪声估得过小。这些步骤给出了模型特有的 EM 更新, 通用单调性条件见第 24 章。噪声接近零时仍须检查边界解与数值条件, 不能把解析 E 步误认为整个学习问题无退化风险。

PPCA 还有与主成分方向直接相连的解。设 $\mathbf{S}_x = n^{-1} \sum_j \mathbf{y}_j \mathbf{y}_j^\top$ 的特征值按 $\lambda_1 \geq \dots \geq \lambda_d$ 排列, 前 q 个特征向量组成 $\mathbf{U}_q$ 。在剩余特征值平均值为正的常规情形下,

$$\begin{aligned} \hat{\sigma}^2 = \frac{1}{d-q} \sum_{i=q+1}^d \lambda_i, \\ \widehat{\mathbf{W}} = \mathbf{U}_q (\mathbf{\Lambda}_q - \hat{\sigma}^2 \mathbf{I}_q)^{1/2} \mathbf{R}_0, \quad \mathbf{R}_0 \mathbf{R}_0^\top = \mathbf{I}_q, \end{aligned} \quad (26.16)$$

其中 $\mathbf{\Lambda}_q = \text{diag}(\lambda_1, \dots, \lambda_q)$ 。这个解为何采用最大特征方向, 可以从负对数似然中的 $\log |\mathbf{C}| + \text{tr}(\mathbf{C}^{-1} \mathbf{S}_x)$ 看出: 固定 $\mathbf{C}$ 的特征值, 迹的重排不等式使最大的观测方差与最大的模型方差对齐。对齐后, 每个自由模型特征值 c_i 的项为 $\log c_i + \lambda_i/c_i$, 其最小值在 $c_i = \lambda_i$; 不能自由变化的 $d-q$ 个方向共用 σ^2 , 对它们的总和求导就得到剩余特征值的平均数。若保留方向之间有重根, 主轴自身也不唯一; 若噪声估计为零, 则落在奇异协方差边界, 不能继续按正定高斯密度使用。PPCA 的似然解及 EM 方法见 Tipping 与 Bishop 的原始论文⁶。

在 $\lambda_i > \hat{\sigma}^2$ 的保留方向上, 把后验均值映回观测空间得到

$$\widehat{\mathbf{W}} \mathbf{m} = \mathbf{U}_q \text{diag} \left(1 - \frac{\hat{\sigma}^2}{\lambda_i} \right)_{i=1}^q \mathbf{U}_q^\top \mathbf{y}.$$

⁶ M. E. Tipping, C. M. Bishop, *Probabilistic Principal Component Analysis* In Journal of the Royal Statistical Society: Series B (Statistical Methodology), 1999, vol. 61, no. 3, pp. 611–622

PCA 的正交投影只保留子空间；PPCA 还按信噪比缩小该子空间内的坐标。在沿固定满列秩载荷令 σ^2 趋于零的极限中，后验均值重构趋近该列空间的正交投影，但零噪声模型本身已不再是全维正密度。这样可以连接降维几何，又不把有噪声的概率推断等同于无噪声投影。

例如，人工设定一个三维样本协方差的特征值为 5, 2, 1，保留一个因子。PPCA 给出 $\hat{\sigma}^2 = (2+1)/2 = 1.5$ ，可以取 $\widehat{\mathbf{W}} = \sqrt{3.5}\mathbf{u}_1$ 。拟合协方差的特征值成为 5, 1.5, 1.5，后两个方向的差异被同方差噪声假设合并。潜变量后验方差为 $(1 + 3.5/1.5)^{-1} = 0.3$ ，后验均值重构则为 $0.7\mathbf{u}_1\mathbf{u}_1^\top \mathbf{y}$ ，而不是 PCA 的完整投影。这个差别是噪声假设的直接后果。

线性高斯模型特别适合解释缺失数据如何改变不确定性。设只观测了索引集 $O \subseteq \{1, \dots, d\}$ ，缺失集为 U 。在式 (26.14) 中用 $\mathbf{W}_{O,:}$ 、 $\Psi_{O,O}$ 和 $\mathbf{x}_O - \mu_O$ 替换相应对象，就得到 $\mathbf{m}_O, \mathbf{s}_O$ 。由于不同观测方向的残余噪声独立，缺失量的条件分布为

$$\begin{aligned}\mathbb{E}[\mathbf{X}_U | \mathbf{x}_O] &= \mu_U + \mathbf{W}_{U,:} \mathbf{m}_O, \\ \text{Cov}(\mathbf{X}_U | \mathbf{x}_O) &= \Psi_{U,U} + \mathbf{W}_{U,:} \mathbf{s}_O \mathbf{W}_{U,:}^\top.\end{aligned}\quad (26.17)$$

预测方差含两部分：未观测传感器自己的噪声，以及共同因子仍不确定所带来的变化。只填入一个条件均值会丢失后者，不能再把填补值当作无误差观测训练后续模型。

示例 26.3 两台传感器对一个连续因子的测量 令 $q = 1, d = 2$ 、 $\mu = \mathbf{0}$ 、 $\mathbf{W} = (1, 2)^\top$ 、 $\Psi = \text{diag}(1, 4)$ 。这是一组人工参数，观测协方差为

$$\mathbf{C} = \begin{pmatrix} 2 & 2 \\ 2 & 8 \end{pmatrix}.$$

若读数为 (2, 4)，潜变量后验精度为 $1 + 1^2/1 + 2^2/4 = 3$ ，线性项为 $1 \times 2/1 + 2 \times 4/4 = 4$ ，因此 $Z | (2, 4) \sim \mathcal{N}(4/3, 1/3)$ 。

若只读取 $X_1 = 2$ ，精度降为 2，于是 $Z | X_1 = 2 \sim \mathcal{N}(1, 1/2)$ 。第二个读数的预测均值为 $2 \times 1 = 2$ ，预测方差为 $4 + 2^2/2 = 6$ 。直接用观测协方差条件化也得到均值 $(2/2) \times 2 = 2$ 与方差 $8 - 2^2/2 = 6$ 。潜变量算法和观测空间的高斯算法给出同一结果。

FA 和 PPCA 仍有**旋转不唯一性** (rotational non-identifiability)：对于任意正交矩阵 $\mathbf{R}_0$ ，把载荷换成 $\mathbf{W}\mathbf{R}_0$ ，并把潜在坐标换成 $\mathbf{R}_0^\top \mathbf{Z}$ ，先验与观测协方差均不变。所以“第一个因子就是某种物理强度”需要额外约束、实验或领域知识支持；一维时连因子的正负号也不能由似然确定。FA 还可能含载荷与独有噪声的额外分解歧义，旋转不是所有不唯一性的完整清单。

对完整记录，利用对角 Ψ 建立 $\mathbf{M}$ 需要 $O(dq^2)$ 操作，分解 $\mathbf{M}$ 需要 $O(q^3)$ ，

随后每条记录的后验均值可用预计算矩阵在 $O(dq)$ 内求得。Woodbury 恒等式与行列式引理还给出

$$\mathbf{C}^{-1} = \Psi^{-1} - \Psi^{-1} \mathbf{W} \mathbf{S} \mathbf{W}^T \Psi^{-1}, \quad |\mathbf{C}| = |\Psi| |\mathbf{M}|,$$

所以似然评价无需分解 $d \times d$ 稠密矩阵。观测完整时，一轮 EM 通常需要 $O(ndq + nq^2 + dq^2 + q^3)$ 操作；噪声更新只计算 $\mathbf{R}$ 所需的对角元素，不必形成整个稠密矩阵。缺失模式相同时可共享后验精度；模式不同时需要分别建立相应矩阵。用有缺失的观测学习参数时，E 步还需纳入缺失量的条件矩，而均值也不能简单取各列已有值的平均。仅对已观测数据最大化似然是否合理，取决于第 24 章讨论的缺失机制与可忽略性条件。

26.2.3 层次结构与混合成员

前面的混合与因子模型默认所有记录使用同一组参数。但同型号设备部署在不同工厂时，工厂间可能相似而不完全相同；同一篇文档中的词也可能来自多个主题。这里要改变的并不是潜变量取离散值还是连续值，而是哪些量在记录之间共享，以及一组记录使用几个成分。

层次模型 (hierarchical model) 通过共享的上层分布联系组级未知量：每个组保留自己的参数，上层参数描述各组之间的共同规律。**板表示法** (plate notation) 用带索引的矩形表示重复的变量与边，避免把整份数据展开成巨大图。一个节点位于组板内、样本板外，表示每组有一个副本，供该组全部样本共享；位于两层板内则表示每个组的每个样本各有一个副本。板不是新的概率因子，板的边框也不表示变量互相连接。给定索引范围后复制节点、展开边，才得到真正用于分解的完整图；这是图模板与实例图的区别。

层次共享可以用一个连续模型直接看出。设组 g 中有 n_g 个测量， $X_{g,j} | \mu_g \sim \mathcal{N}(\mu_g, \sigma^2)$ ，且 $\mu_g \sim \mathcal{N}(m_0, \tau^2)$ 。给定各组均值后，各测量相互独立；给定上层参数后，各组均值也相互独立。在 m_0 已知且 σ^2, τ^2 为已知正数时，组内均值为 $\bar{x}_g$ ，平方配方得到

$$\begin{aligned} \mathbb{E}[\mu_g | \mathbf{x}_g] &= a_g \bar{x}_g + (1 - a_g) m_0, \\ a_g &= \frac{n_g \tau^2}{\sigma^2 + n_g \tau^2}, \\ \text{Var}(\mu_g | \mathbf{x}_g) &= (\tau^{-2} + n_g \sigma^{-2})^{-1}. \end{aligned} \tag{26.18}$$

组内观测少或噪声大时，结果更多依赖共享均值 m_0 ；观测多时，更多依赖组内均值。这称为**部分汇聚** (partial pooling)，即不强迫各组参数相同，也不让各组完全独立估计。人工设定 $m_0 = 0, \tau^2 = 1, \sigma^2 = 4, \bar{x}_g = 3$ 时， $n_g = 2$ 得到后验均值 1， $n_g = 20$ 得到 2.5。差异来自证据量，不是人为给

小组降低权重。

需要区分“共享一个已知先验”和“从其他组学习先验”。若 m_0, τ^2 固定已知，其他组的新增数据不会改变本组后验；若用全部组的数据估计它们，或再对它们设置先验并联合推断，各组才通过这些未知共享量传递信息。例如执行 EM 时，把组级随机量 μ_g 作为未观测量，在 E 步计算其后验矩；在共同 τ^2 下，M 步将 m_0 更新为各组 $E[\mu_g | \mathcal{D}]$ 的平均，而不是给每组单独拟合一个 m_0 。这里的 μ_g 不是漏记的数据字段。完全贝叶斯推断还积分共享参数的不确定性。组间规律不相似时，错误汇聚会引入偏差，所以组级分布也是需要检验的假设。

与层次共享相关但不同的结构是**混合成员** (mixed membership)：同一个观测组包含多个局部成分分配，而不是整组只选一次成分。例如一篇文档可以同时讨论设备和维修；每个词选择一个主题，文档级主题比例控制这些选择。此处的“主题”是词的概率分布，不保证等同于人类预先给定的类别。设文档索引为 $g = 1, \dots, G$ ，长度为 N_g ，词表有 v 个词， $X_{g,j} \in \{1, \dots, v\}$ 为第 j 个词的编号。主题 k 的词概率向量为 β_k ，文档主题比例为 π_g ，二者各自非负且分量和为 1。

概率潜在语义分析 (probabilistic latent semantic analysis, pLSA) 给训练语料中的每篇文档配置一个固定的 π_g 。在给定文档编号后，每个词先取主题 $Z_{g,j} \sim \text{Categorical}(\pi_g)$ ，再从 $\beta_{Z_{g,j}}$ 抽词，因此

$$p(\mathbf{x}_g | \pi_g, \beta_{1:K}) = \prod_{j=1}^{N_g} \sum_{k=1}^K \pi_{g,k} \beta_{k,x_{g,j}}. \quad (26.19)$$

式中 Categorical 表示取一个类别的分布， $\beta_{k,a}$ 为主题 k 生成词 a 的概率。每个词有自己的主题，所以这不是“每篇文档一个主题”的有限混合。对固定参数，每个词的主题后验正比于 $\pi_{g,k} \beta_{k,x_{g,j}}$ ，且不同位置的主题后验独立；每轮 EM 可以用这些责任度更新 $\pi_{g,k}$ 为该文档的平均主题责任度，再用全语料的主题加权词频更新 β_k 。词频表示可合并重复词的计算。pLSA 的混合分解与 EM 形式见 Hofmann 的原始论文⁷。

pLSA 对已有文档编号与词定义了合法分布，但文档比例参数的数量随训练文档数增长：仅这部分就需要 $G(K-1)$ 个自由参数。面对一篇未见文档，可以固定主题后再拟合新比例，这称为折入估计；然而原模型没有给出新文档比例如何随机产生的分布。因此其局限不是“没有归一化”，而是缺少对新文档级比例的概率生成说明。

潜在狄利克雷分配 (latent Dirichlet allocation, LDA) 把文档比例改为随机变量，让每篇新文档都从同一个先验抽取自己的主题比例。取 $\alpha_k > 0$ 、

⁷ T. Hofmann, *Probabilistic Latent Semantic Analysis* In Proceedings of the Fifteenth Conference on Uncertainty in Artificial Intelligence, 1999, pp. 289–296

$\alpha_0 = \sum_k \alpha_k$, 狄利克雷分布在单纯形内部的密度为

$$p(\pi_g | \alpha) = \frac{\Gamma(\alpha_0)}{\prod_k \Gamma(\alpha_k)} \prod_{k=1}^K \pi_{g,k}^{\alpha_k-1}.$$

其均值为 α_k/α_0 ; 固定均值比例时, α_0 越大, 文档比例越集中在该均值附近。随后仍为每个词抽主题与词值。条件于固定主题分布, 文档的联合分布与边缘分布分别为

$$\begin{aligned} p(\pi_g, \mathbf{z}_g, \mathbf{x}_g | \alpha, \beta_{1:K}) &= p(\pi_g | \alpha) \prod_j \pi_{g,z_{g,j}} \beta_{z_{g,j}, x_{g,j}}, \\ p(\mathbf{x}_g | \alpha, \beta_{1:K}) &= \int p(\pi_g | \alpha) \prod_j \left(\sum_k \pi_{g,k} \beta_{k, x_{g,j}} \right) d\pi_g. \end{aligned} \quad (26.20)$$

这里条件于文档长度, 不另外拟合长度分布。 α 与主题词分布用于所有文档, 新文档无需增加一组固定的待学习比例参数; 其比例进入后验推断。所谓完整生成语义, 是在这个固定长度设定下能说明一篇新文档如何生成, 并不意味着模型解释了语法或词序。

给定 π_g 后, 词的位置独立同分布; 把共享比例积分掉后, 词之间一般相关, 但文档概率对位置排列不变。这是词袋模型的可交换性, 不是边缘独立性。若以词计数向量而不是一个有序的词值列表作为样本, 还应乘上相应的多项式计数系数。LDA 通过随机文档比例补足了 pLSA 的组级生成说明, 同时引入需要积分的连续潜变量; 原始论文给出了模型、变分推断与经验贝叶斯学习⁸。

⁸ D. M. Blei, A. Y. Ng, M. I. Jordan, *Latent Dirichlet Allocation* In *Journal of Machine Learning Research*, 2003, vol. 3, pp. 993–1022

示例 26.4 固定比例、随机比例与整组单一主题 设词表为 $\{a, b\}$, 两个主题为 $\beta_1 = (0.8, 0.2)$ 和 $\beta_2 = (0.2, 0.8)$ 。在 LDA 中取 $\alpha = (1, 1)$, 于是 $\pi_{g,1} = u$ 在 $[0, 1]$ 上均匀分布, $\pi_{g,2} = 1 - u$ 。一个词取 a 的条件概率为 $0.2 + 0.6u$, 其边缘概率为 $1/2$ 。连续观察到两个 a 的概率为

$$p(a, a) = \int_0^1 (0.2 + 0.6u)^2 du = 0.04 + 0.12 + 0.12 = 0.28.$$

若把文档比例固定成 $(1/2, 1/2)$, 式 (26.19) 给出 $0.5^2 = 0.25$ 。若整篇文档只抽一次主题, 则概率为 $(0.8^2 + 0.2^2)/2 = 0.34$ 。三者单词边缘相同, 两个词的联合概率却不同。

LDA 中主题配置 $(1, 1), (1, 2), (2, 1), (2, 2)$ 与观测 (a, a) 的联合概率依次为 $16/75, 2/75, 2/75, 1/75$ 。例如第一个数是 $\int_0^1 u^2 du \times 0.8^2$, 第二个数是 $\int_0^1 u(1-u) du \times 0.8 \times 0.2$ 。归一化后, 四种配置的后验权重

为 $16/21, 2/21, 2/21, 1/21$, 故

$$p(\pi_g | a, a) = \frac{16}{21} \text{Dirichlet}(3, 1) + \frac{4}{21} \text{Dirichlet}(2, 2) + \frac{1}{21} \text{Dirichlet}(1, 3).$$

后验均值 $E[\pi_{g,1} | a, a] = 19/28$, 下一词为 a 的预测概率为 $0.2 + 0.6 \times 19/28 = 17/28$ 。后验是狄利克雷分布的混合, 而不是把未知主题简单计数后得到的单个狄利克雷分布。

这个小例子揭示了 LDA 推断的困难。如果所有主题标签已知, 令 $n_{g,k}$ 为文档 g 中分到主题 k 的词数, 则共轭性给出 $\pi_g | \mathbf{z}_g \sim \text{Dirichlet}(\boldsymbol{\alpha} + \mathbf{n}_g)$ 。只有词可观测时, 需要对主题配置求和; 长文档有 K^{N_g} 种配置, 直接枚举迅速不可行。局部共轭不等于整个后验有简单闭式解, 固定一个比例点也不等于积分比例的不确定性。

可以进一步给主题词分布设置 $\beta_k \sim \text{Dirichlet}(\boldsymbol{\eta})$, 其中 $\eta_a > 0$, 由此得到图 26.3 的贝叶斯扩展。 β_k 跨全部文档共享; π_g 只在一篇文档内共享; $\mathbf{z}_{g,j}$ 逐词变化。图中同时出现连续比例与离散分配, 说明一个混合成员模型本来就可以包含两类潜变量。




图 26.3 主题词分布也带先验的 LDA 板图。空心圆为随机潜在量, 填色圆为观测词, 实点为给定超参数。 G 个文档分别有主题比例 π_g , 每篇有 N_g 个主题分配和词; K 个主题词分布 β_k 在所有文档间共享。指向词的主题参数边表示按 $z_{g,j}$ 选择对应分布。

模型特有的后验计算可以接回前面的通用工具。固定 $\beta_{1:K}$ 时, 采用 $q(\pi_g) \prod_j q(z_{g,j})$ 的平均场近似, 令 $q(\pi_g) = \text{Dirichlet}(\boldsymbol{\gamma}_g)$ 、 $q(z_{g,j} = k) = \rho_{g,j,k}$, 其坐标更新为

$$\begin{aligned} \rho_{g,j,k} &\propto \beta_{k,x_{g,j}} \exp \left\{ \psi(\gamma_{g,k}) - \psi \left(\sum_{\ell} \gamma_{g,\ell} \right) \right\}, \\ \gamma_{g,k} &= \alpha_k + \sum_j \rho_{g,j,k}. \end{aligned} \quad (26.21)$$

这里 $\psi(u) = d \log \Gamma(u)/du$ 为 digamma 函数, 花括号中的量就是 q 下 $\log \pi_{g,k}$ 的期望。 γ_g 和 ρ_g 共同组成局部变分参数 ϕ_g 。对每个词归一化 ρ 后交替更新, 两式正是第 22 章坐标上升在该模型中的实例, 而不是精确后验等式。固定全局参数时, 一轮稠密局部更新通常需 $O(K \sum_g N_g)$ 操作。

给 β_k 也加狄利克雷先验后, 可以把 π_g 与 β_k 积分掉, 使用第 23 章的 Gibbs 方法更新一个主题分配。令 $n_{g,k}^-$ 为排除当前位置后的文档主题计数, $c_{k,a}^-$ 为全语料的主题词计数, $c_{k,\cdot}^- = \sum_a c_{k,a}^-$ 、 $\eta_0 = \sum_a \eta_a$, 则

$$p(Z_{g,j} = k \mid \text{其余分配}, \mathcal{D}) \propto (n_{g,k}^- + \alpha_k) \frac{c_{k,x_{g,j}}^- + \eta_{x_{g,j}}}{c_{k,\cdot}^- + \eta_0}. \quad (26.22)$$

第一项来自该文档对主题的后验预测, 第二项来自主题对当前词的后验预测; 与 k 无关的文档分母已约去。两项相乘再归一化, 是积分共轭分布后得到的精确单点条件概率, 但有限次采样得到的整体后验估计仍有误差, 且可能混合缓慢。

将主题词参数作点估计时, 变分 EM 在 E 步固定当前参数完成局部推断, 随后在 M 步用 ρ 加权的全语料词频更新主题词概率。对 α 的 M 步涉及 $\log \Gamma(\alpha_0) - \sum_k \log \Gamma(\alpha_k)$ 及各文档的 $\mathbb{E}_q[\log \pi_{g,k}]$, 可在正值约束下数值优化。把变分期望当作真后验期望, 只能得到变分目标的性质, 不能宣称观测似然按精确 EM 保证上升。采用贝叶斯主题参数时, 所更新的是相应参数后验或变分因子, 不再是同一个点估计问题; 这些区别回到第 24 章的学习目标选择。

主题模型同样存在标签交换。在对主题对称的先验下, 主题编号与比例坐标可以共同置换; 即使通过非对称先验固定了一些编号, 主题词分布也未必由有限语料唯一识别。两个主题几乎相同、文档过短或主题数过大时, 分解尤其不稳定。词袋假设忽略词序, 而主题比例的先验又限制组间变化; 较高的似然不能证明学到了唯一、可命名的语义主题。

固定 K 还要求在拟合之前选定成分数。**狄利克雷过程混合** (Dirichlet process mixture, DPM) 用随机离散分布为潜在成分提供可数无限的候选集合, 使有限数据实际占用的成分数可以变化。狄利克雷过程 $G \sim \text{DP}(c, H)$ 是“概率分布上的分布”: $c > 0$ 为浓度参数, H 为成分参数空间上的基准概率分布。对任意有限可测分割 $B_1, \dots, B_L$, 它满足

$$(G(B_1), \dots, G(B_L)) \sim \text{Dirichlet}(cH(B_1), \dots, cH(B_L)),$$

基准概率为零的集合对应恒为零的坐标, 可从狄利克雷向量中移去。此定义约束所有有限分割, 不能仅把一个有限狄利克雷向量的维数写成无穷。

一种具体构造是取独立 $v_k \sim \text{Beta}(1, c)$ 与 $\xi_k \sim H$, 令

$$w_k = v_k \prod_{\ell < k} (1 - v_\ell), \quad G = \sum_{k=1}^{\infty} w_k \delta_{\xi_k}.$$

其中 δ_{ξ_k} 把全部质量放在成分参数 ξ_k 上, 权重和几乎必然为 1。再令每条记录的参数 $\zeta_j | G \sim G$, $\mathbf{X}_j | \zeta_j \sim p(\cdot | \zeta_j)$, 重复抽到同一原子就意味着共享同一成分。基准分布连续不妨碍 G 的抽样结果几乎必然离散; 观测仍可具有连续密度, 例如高斯成分混合。

在 H 无原子时, 将 G 积分掉, 给定前 n 个潜在成分参数, 下一条记录复用已有成分 k 的概率为 $n_k/(n+c)$, 抽取新成分的总概率为 $c/(n+c)$ 。例如已有占用数为 (3,1) 且 $c=1$, 三个选择的概率为 0.6, 0.2, 0.2。这是给定潜在分配后的先验预测; 若下一条记录的观测值也已给出, 还要分别乘成分预测密度与基准预测密度, 再归一化。有限 n 最多占用 n 个成分; 其先验期望为 $\sum_{j=1}^n c/(c+j-1)$, 因为第 j 次抽样新增成分的概率就是该和的第 j 项。“无限”放宽的是候选模型容量, 不是要求实际计算无限个成分, 也不是保证恢复某个真实有限类别数。

多个组需要共同使用这些候选成分时, 分别从同一个连续 H 抽取独立狄利克雷过程还不够: 不同组的原子几乎必然不同, 不能精确共享成分。**层次狄利克雷过程** (hierarchical Dirichlet process, HDP) 改用一个离散的随机基准分布:

$$G_0 \sim \text{DP}(\gamma, H), \quad G_g | G_0 \sim \text{DP}(c, G_0). \quad (26.23)$$

由于 G_0 几乎必然离散, 各 G_g 的原子来自同一个可数集合, 但组级权重可以不同。用于主题建模时, 原子是主题词分布, 文档的每个词选择一个共享主题, 文档之间又有不同偏好。这同时具有层次共享、混合成员和非固定成分数量, 而不是在三者之间择一。DP 的离散构造及 HDP 如何通过随机基准共享原子, 可参看 Teh 等人的系统论述⁹。

DPM 与 HDP 把“选择一个固定 K ”转化为对分配、权重和超参数的联合推断, 计算负担并未消失。截断变分方法用有限候选集近似无限模型, 采样方法可以动态增删已占用成分; 二者分别需要检查截断误差或链的混合。HDP 还要处理组内成分与全局共享成分的关系, 不能只在各组独立运行有限混合 EM。浓度参数仍控制分组倾向, 超参数估计与预测检验仍然必要。随机原子的编号也不赋予语义可识别性; 实际应报告预测、占用成分和组间共享的不确定性, 而不是只给一个未经验证的“自动主题数”。

⁹ Y. W. Teh, M. I. Jordan, M. J. Beal, D. M. Blei, *Hierarchical Dirichlet Processes* In Journal of the American Statistical Association, 2006, vol. 101, no. 476, pp. 1566–1581

26.3 模型比较

比较这些模型前，应固定要回答的查询。下表中的“观测似然”指给定全局参数或超参数后，对模型规定的局部潜变量完成边缘化的 $p(\mathbf{x})$ ，不是再对所有未知参数积分得到的模型证据。NB 与 TAN 按完整训练记录 $(y, \mathbf{x})$ 比较，分类查询则把 Y 当作未知量。表 26.1 同时列出独立性、共享方式与非唯一性，以免把“潜变量存在”和“后验必然难算”混为一谈。

模型与潜在量	独立性与共享	观测似然	局部后验	非唯一性与主要代价
NB / TAN: 训练时无潜变量	类内独立/类内树；参数跨样本共享	完整记录直接乘积	类别后验枚举 K 项	支持不足的条件表不确定；TAN 还需选择树
自回归：无随机潜变量	顺序父集；条件网络可共享参数	条件密度直接乘积	前缀续写直接；任意补全未必易算	网络参数可不唯一；优化、顺序选择与串行生成
有限混合：离散分配	样本在固定参数下独立；类内结构由成分决定	K 项有限和	成分责任度精确	标签交换、冗余成分；局部极值与退化
FA / PPCA: 连续因子	给定因子后观测独立；共享载荷	解析高斯密度	解析高斯后验与缺失预测	旋转及可能的额外分解歧义；维数与噪声假设
LDA: 连续比例与离散主题	组级比例、全局主题；组内条件独立	需积分比例，通常近似	联合后验通常近似，局部条件可解析	主题置换与重叠；局部推断和全局学习交替
DPM / HDP: 分配与随机测度	可数候选成分；HDP 跨组共享原子	对未知随机量积分通常需近似	采样或截断变分	成分编号不唯一；占用数、超参数与近似误差

表 26.1 静态有向模型的查询与计算比较。“精确”均指所述固定参数设定下的局部计算，不意味着参数已知、学习有全局保证或模型能唯一解释数据。

直接分解把联合建模转化为局部条件分布的拟合。NB 用强独立性节省样本，TAN 增加少量结构搜索，自回归网络则把更多表达负担交给参数共享与非线性优化。它们避免的是完整观测似然中的潜变量求和或积分；顺序采样、任意缺失查询和条件模型失配仍可能成为瓶颈。潜变量模型也不都需要近似推断：有限混合的有限和、线性高斯模型的解析积分，都能同时给出精确似然与局部后验。

组级共享改变了推断问题的规模。pLSA 在固定文档比例下只有逐词有限和；LDA 把比例作为共同随机量后，同一文档的主题后验相互联系；再给主题分布加先验，又联系起不同文档。HDP 进一步让候选成分数量参与推断。因此层次模型的计算困难不只来自单个潜变量取值空间大，也来自多个局部未知量必须共同解释共享观测。

这些属性可以组合。例如混合因子分析先选离散成分，再用该成分的连续因子生成观测；每个成分边缘化后仍是一个低秩加对角协方差的高斯，责任度与因子后验都可解析计算。自回归条件也可以用有限混合参数化，组级载荷可以再设置层次先验。是否采用离散潜变量、是否线性高斯、是否跨组共享、是否逐项生成，应按不同维度分别回答，而不根据一个模型名称一次决定。

可识别性则约束结果能怎样解释。给定充分数据，条件概率或观测协方

差可能估计得很准确，但这不自动识别网络的每个权重、混合的编号或因子的方向。模型选择应结合留出预测与建模目标：若要解释潜在结构，还需报告这些对称性及稳定性；若主要用于补全，则应检验条件预测与不确定性，而不是只比较完整记录的似然。计算可行、预测有效和潜在解释可信，是需要分别验证的三项判断。

26.4 本章小结

静态有向模型用局部条件分布定义联合分布，但观测分布可以来自两种不同计算过程：直接评价全部观测节点的分解，或在更大的联合分布中消去潜变量。两个传感器的例子说明，同一张观测概率表既可以写成自回归条件，也可以写成隐藏类别的混合；前者给出预测顺序，后者提供一个需要另行验证的潜在解释。

潜变量改变的不只是模型图形。有限混合把学习变成责任度与成分参数的交替估计，却保留精确的局部后验；线性高斯模型用解析积分连接协方差、降维表示和缺失预测；层次结构与混合成员把多个样本或组的未知量联系起来，常使联合后验需要近似计算。离散或连续描述潜变量的取值，层次或混合成员描述共享方式，二者可以共同出现。标签交换、旋转和冗余分解进一步表明，观测分布的确定性不等于潜在坐标的唯一性。

面对一个新模型，应检查它如何归一化、目标查询需要消去哪些变量、哪些量在数据之间共享，以及参数估计是否受到退化或非唯一性的影响。接下来的第 27 章改用对称相互作用组织模型，比较联合归一化与只对输出归一化的差别。神经参数化不会取消这些概率问题；第 29 章再以本章的自回归分解和高斯潜变量模型为参照，比较更灵活的密度构造。

静态无向模型

一排检测位置的状态通常不是彼此独立的：相邻位置可能共同过热，也可能因同一种测量干扰而同时出现异常。若已经知道每个位置的局部偏好和相邻位置的相容程度，怎样把这些信息组成整排状态的概率？如果温度读数已经给定，任务只剩下预测各位置的异常标签，又是否还需要解释这些读数本身怎样产生？

这两个问题共享局部势函数，却有不同归一化对象。联合无向模型为所有建模变量的配置分配概率；条件无向模型固定输入，只比较可能的输出配置。第 18 章已经建立无向分解与条件独立的联系，本章据此选择具体分布，考察哪些结构使推断可计算，以及增加潜变量、扩大势的作用域或改用神经参数化后，计算困难转移到了哪里。联合与条件是这里的主分类轴；观测或潜变量、成对或高阶势、固定特征或神经参数化都是可以交叉的属性，并非互斥的模型类别。

27.1 无向模型的共同形式

设无向图为 $\mathcal{G} = (V, E)$ ， $d = |V|$ ，节点变量组成 $\mathbf{X} = (X_1, \dots, X_d)^\top$ 。若某个局部配置符合建模偏好，就给它较大的**势函数**（potential function）值；势表达的是相对相容程度，不要求其自身求和为 1。以 $\mathcal{C}$ 表示所用因子的作用域集合，每个 $C \in \mathcal{C}$ 都是图中的一个团，不必是极大团。对严格正的势 $\psi_{\theta,C}$ ，定义局部能量 $E_{\theta,C} = -\log \psi_{\theta,C}$ ，便得到

$$\begin{aligned} E_{\theta}(\mathbf{x}) &= \sum_{C \in \mathcal{C}} E_{\theta,C}(\mathbf{x}_C), \\ p_{\theta}(\mathbf{x}) &= \frac{\prod_{C \in \mathcal{C}} \psi_{\theta,C}(\mathbf{x}_C)}{Z_{\theta}} = \frac{\exp[-E_{\theta}(\mathbf{x})]}{Z_{\theta}}, \\ Z_{\theta} &= \int \exp[-E_{\theta}(\mathbf{u})] d\mu(\mathbf{u}). \end{aligned} \quad (27.1)$$

这里 θ 收集所有参数， μ 在离散空间上是计数测度，在连续空间上是指定的基准测度，通常为 Lebesgue 测度。**能量函数**（energy function）把局部偏好加起来，数值越小的配置具有越大的未归一化权重；**配分函数**（partition

function) Z_θ 则把所有配置的权重汇总, 要求 $0 < Z_\theta < \infty$ 。本章的能量是无量纲的对数权重, 物理模型中的逆温度已吸收到参数里。

负能量 $f_\theta = -E_\theta$ 也可作为得分, 但它还不是对数概率; 后者是 $f_\theta - \log Z_\theta$ 。给能量加一个不依赖 $\mathbf{x}$ 的常数, 只会同时缩放分子与配分函数, 不改变分布; 把能量乘以一个正数则通常会改变分布的集中程度。比较同一个模型内两种配置时, 配分函数约去:

$$\frac{p_\theta(\mathbf{x})}{p_\theta(\mathbf{x}')} = \exp\{E_\theta(\mathbf{x}') - E_\theta(\mathbf{x})\}.$$

这使得能量差足以排序配置, 却不足以给出某一配置的绝对概率。只修改一个局部势, 也会改变 Z_θ , 进而改变其他配置的概率; 局部参数正是通过这个总和与全局分布联系起来。

当输入 $\mathbf{x}$ 已经给定、输出为 $\mathbf{Y}$ 时, 保留相同构造, 但把求和或积分限制在输出空间:

$$p_\theta(\mathbf{y} | \mathbf{x}) = \frac{\exp[-E_\theta(\mathbf{y}, \mathbf{x})]}{Z_\theta(\mathbf{x})}, \quad (27.2)$$

$$Z_\theta(\mathbf{x}) = \int \exp[-E_\theta(\mathbf{v}, \mathbf{x})] d\mu_Y(\mathbf{v}).$$

每个实际使用的输入都必须满足 $0 < Z_\theta(\mathbf{x}) < \infty$ 。这没有定义 $p(\mathbf{x})$: 输入之间可以有复杂依赖, 模型不负责给它们分配生成概率。相应地, 任意只依赖输入的附加能量 $c(\mathbf{x})$ 都会约掉。图 27.1 强调了这一差别: 条件无向模型中的输入可以影响多个势, 但不参与本次归一化。

有限离散状态、有限能量自动给出正且有限的配分函数。连续空间没有这一便利: $E(x) = -x^2$ 处处有定义, 但 $\int_{\mathbb{R}} e^{x^2} dx$ 发散。若允许零势, 可将对应能量记为 $+\infty$ 来排除某些配置; 此时须保留至少一个有正权重的离散配置, 连续情形则须保留正测度的有效支持。零势不妨碍由分解推出 Markov 性质, 但不能直接调用要求严格正性的反向分解定理。有关条件已在第 18 章说明。


27.2 联合能量模型

联合建模适合需要补全未知状态、计算多变量事件概率或生成整组配置的任务。下面从成对作用出发, 分别改变变量是否可见、能量的函数形式和势的作用域。每次变化都保留式 (27.1), 但可用的推断运算并不相同。

27.2.1 观测变量成对模型


当每个位置只有两种状态时, 可用 $x_i \in \{-1, +1\}$ 表示。Ising 模型 (Ising model) 用一个参数描述每个位置偏向哪种状态, 再用一个参数描述每对

联合：对整组状态归一化



$$Z = \sum_{\mathbf{x}} \psi_{1,2}(x_1, x_2) \psi_{2,3}(x_2, x_3)$$

条件：固定输入，只对标签归一化



$$Z(\mathbf{x}) = \sum_{\mathbf{y}} \exp[-E(\mathbf{y}, \mathbf{x})]$$

----- 虚线：非概率依赖（特征读入）

图 27.1 相同的三节点相互作用可以用于联合或条件建模。上图对整组状态求和；下图用灰底框把 $\mathbf{x}$ 明确标成 evidence / context，只对标签 $\mathbf{y}$ 求和。图内图例说明虚线是特征读入形成的非概率依赖，不是概率图中的有向生成边。

相邻位置偏好同号还是异号：

$$E_{\theta}(\mathbf{x}) = - \sum_{i \in V} b_i x_i - \sum_{\{i,j\} \in E} J_{i,j} x_i x_j. \quad (27.3)$$

b_i 称为**外场**（external field），正值偏好 +1； $J_{i,j}$ 是**耦合参数**（coupling parameter），正值奖励同号，负值奖励异号。每条无向边只计算一次，且记 $J_{i,j} = J_{j,i}$ 。无向耦合描述统计相互作用，不意味着干预一个节点会按该参数改变另一个节点。

固定其余节点后，含 x_i 的得分只有 $x_i(b_i + \sum_{j \in N(i)} J_{i,j} x_j)$ ，其中 $N(i)$ 是邻居集合。因此两种状态的权重比为 $\exp[2(b_i + \sum_j J_{i,j} x_j)]$ ，从而

$$p_{\theta}(X_i = +1 \mid \mathbf{x}_{V \setminus \{i\}}) = \sigma \left(2b_i + 2 \sum_{j \in N(i)} J_{i,j} x_j \right), \quad (27.4)$$

$$\sigma(u) = \frac{1}{1 + e^{-u}}.$$

只需邻居的状态便可计算满条件概率，但这不表示无边节点在未给定邻居时独立。

以三个相邻检测位置为教学例子，图为 1-2-3，没有单点偏好，每条边的势在同号时为 3、异号时为 1。这些数值是人为设定的相容权重，不

是测量频率。记相同相邻对的数量为

$$N_{=}(x) = \mathbf{1}\{x_1 = x_2\} + \mathbf{1}\{x_2 = x_3\}.$$

选取能量 $E_0(x) = -(\log 3)N_{=}(x)$, 联合权重为 $3^{N_{=}(x)}$ 。由于 x_1 有两种选择, 每个后继状态的权重和均为 $3 + 1 = 4$, 配分函数为 $Z_0 = 2 \times 4 \times 4 = 32$ 。这是 $J_{1,2} = J_{2,3} = (\log 3)/2$ 的 Ising 模型, 因为 $\mathbf{1}\{x_i = x_j\} = (1 + x_i x_j)/2$ 。不过, E_0 比式 (27.3) 的零外场能量少一个常数 $\log 3$, 所以按后者计算的配分函数为 $32/3$; 分布相同, 配分函数的数值不必相同。

在这个对称链上, 给定前一个位置, 后一个位置与它同号的概率为 $3/4$, 异号的概率为 $1/4$ 。两端同号可以经过两次保持或两次改变, 因此

$$p(X_3 = X_1 | X_1) = (3/4)^2 + (1/4)^2 = \frac{5}{8}.$$

每个节点的边缘概率都是 $1/2$, 于是 $\mathbb{E}[X_1 X_3] = 2(5/8) - 1 = 1/4$ 。虽然 1 与 3 没有直接相连, 它们仍相关; 给定 X_2 后才独立。对同样的更长零外场链, 每条边使条件均值乘以 $1/2$, 相隔 r 条边的相关为 $(1/2)^r$ 。局部相互作用可以沿路径传递, 传递强度依赖参数, 而非只取决于是否相邻。

若每个位置有 $K > 2$ 个类别, 类别编号的乘积不再有自然含义。**Potts 模型** (Potts model) 以“类别是否相同”表达相容性, 对 $x_i \in \{1, \dots, K\}$ 取

$$E_{\theta}(x) = -\sum_i b_i(x_i) - \sum_{\{i,j\} \in E} J_{i,j} \mathbf{1}\{x_i = x_j\}. \quad (27.5)$$

$b_i(k)$ 是位置 i 对类别 k 的偏好。固定邻居后, 对各候选类别计算权重

$$w_i(k) = \exp \left\{ b_i(k) + \sum_{j \in N(i)} J_{i,j} \mathbf{1}\{k = x_j\} \right\},$$

再除以 $\sum_{\ell=1}^K w_i(\ell)$, 便得到节点 i 的满条件概率。所有类别相等与否共用一个边参数, 这是有意施加的限制; 若某两种不同类别特别相容, 就需要一般的 $K \times K$ 边势表。二类 Potts 在重新编码后与 Ising 相容, 但耦合系数相差上面的 $1/2$, 不能不经转换直接比较。

学习这两类模型时, 一条完整记录给出节点取值和边上的乘积或同类指示量。固定图后, 最大似然要求这些经验统计量与模型期望匹配; 例如 Ising 的 $J_{i,j}$ 更新使用经验 $x_i x_j$ 减去模型的 $\mathbb{E}[X_i X_j]$ 。通用梯度与替代准则见第 24 章。模型特有的便利是式 (27.4) 可直接用于 Gibbs 更新或伪似然拟合; 限制则是邻居之间强耦合时, 单点更新可能很难从一种整体配置走到另一种。

在树上, 用一般稠密边势计算配分函数和边缘需要 $O(dK^2)$ 运算, 特殊势还能进一步化简。一般图的精确消元则受诱导宽度控制, 不能因为每个

原始因子只含两个变量，就断言整个计算是二次复杂度。二值吸引型模型的最优配置可以用第 22 章的图割方法求解，但最优配置容易求不等于配分函数容易求。过强的同类偏好还可能把真实的局部异常抹平；负耦合构成的环也可能让相邻偏好无法同时满足。例如三角形的三条边都要求异号时，任一二值配置至少违反一条边。

连续测量需要另一种局部势。**高斯 Markov 随机场** (Gaussian Markov random field, GMRF) 用二次能量表示整组连续变量，并由精度矩阵控制条件依赖。对 $\mathbf{x} \in \mathbb{R}^d$ ，令

$$\begin{aligned} E_{\theta}(\mathbf{x}) &= \frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^{\top} \mathbf{Q}(\mathbf{x} - \boldsymbol{\mu}), \\ Z_{\theta} &= (2\pi)^{d/2} |\mathbf{Q}|^{-1/2}, \quad \mathbf{Q} = \mathbf{Q}^{\top} > 0. \end{aligned} \quad (27.6)$$

$\boldsymbol{\mu}$ 为均值， $\mathbf{Q}$ 是协方差的逆，称为**精度矩阵** (precision matrix)。正定性同时保证二次能量在各方向有足够增长，并保证高斯密度可归一化。给定其他节点后，

$$\begin{aligned} \tilde{\mu}_i(\mathbf{x}) &= \mu_i - \frac{1}{Q_{i,i}} \sum_{j \neq i} Q_{i,j} (x_j - \mu_j), \\ X_i \mid \mathbf{x}_{V \setminus \{i\}} &\sim \mathcal{N}(\tilde{\mu}_i(\mathbf{x}), Q_{i,i}^{-1}). \end{aligned}$$

其中 $\tilde{\mu}_i$ 为条件均值。在非退化高斯条件下， $Q_{i,j} = 0$ 当且仅当 $X_i \perp X_j \mid \mathbf{X}_{V \setminus \{i,j\}}$ 。这里判别的是条件独立，不是协方差为零；一般证明可回顾第 18 章。

例如，对三个位置的标准化温度取零均值和

$$\mathbf{Q} = \begin{pmatrix} 2 & -1 & 0 \\ -1 & 2 & -1 \\ 0 & -1 & 2 \end{pmatrix}, \quad \mathbf{Q}^{-1} = \frac{1}{4} \begin{pmatrix} 3 & 2 & 1 \\ 2 & 4 & 2 \\ 1 & 2 & 3 \end{pmatrix}.$$

顺序主子式为 2, 3, 4，可核验 $\mathbf{Q} > 0$ 。两端精度元素为零，但协方差为 1/4，与离散链一样存在经中点传递的边缘关联。若 $x_1 = 2, x_3 = 0$ ，中点的条件分布是 $\mathcal{N}(1, 1/2)$ ；条件均值给出补全值，条件方差保留剩余不确定性。

高斯模型的推断归结为线性方程求解和矩阵分解。稠密 Cholesky 分解需要 $O(d^3)$ 时间，之后可以求解条件均值、取得所需协方差项和计算对数行列式；对固定带宽的链状精度，分解成本可随 d 线性增长。一般稀疏矩阵仍可能在消元中产生填充，稀疏不自动等于线性时间。若均值已知为零，样本二阶矩为 $\mathbf{S} = n^{-1} \sum_{r=1}^n \mathbf{x}_r \mathbf{x}_r^{\top}$ ，学习精度所需最大化的部分是

$$\frac{n}{2} \{\log |\mathbf{Q}| - \text{tr}(\mathbf{S}\mathbf{Q})\}, \quad \mathbf{Q} > 0,$$

并对缺边位置施加 $Q_{i,j} = 0$ 。无图约束且 $\mathbf{S} > 0$ 时解为 $\mathbf{S}^{-1}$ ；有零元素约束时一般要做约束优化。仅有半正定精度不能在整个 $\mathbb{R}^d$ 上定义式 (27.6)，单个高斯也不能表示多峰分布。这是解析计算所伴随的表示限制，而非增加

迭代次数能够解决的问题¹。

27.2.2 潜变量能量模型

若多个位置共同异常,但记录中没有直接测量产生这种共同变化的状态,可以引入潜变量,让其连接若干可见位置。**玻尔兹曼机** (Boltzmann machine, BM) 在二值可见变量与隐藏变量的联合空间上定义成对能量,再通过边缘化隐藏变量得到数据分布。本节改用 0/1 编码,记可见向量 $\mathbf{x} \in \{0, 1\}^{d_v}$ 、隐藏向量 $\mathbf{z} \in \{0, 1\}^m$, 总节点数为 $d_v + m$:

$$\begin{aligned} E_{\theta}(\mathbf{x}, \mathbf{z}) &= -\mathbf{b}^{\top} \mathbf{x} - \mathbf{c}^{\top} \mathbf{z} - \mathbf{x}^{\top} \mathbf{W} \mathbf{z} \\ &\quad - \frac{1}{2} \mathbf{x}^{\top} \mathbf{U} \mathbf{x} - \frac{1}{2} \mathbf{z}^{\top} \mathbf{R} \mathbf{z}, \\ p_{\theta}(\mathbf{x}, \mathbf{z}) &= \frac{e^{-E_{\theta}(\mathbf{x}, \mathbf{z})}}{Z_{\theta}}, \\ p_{\theta}(\mathbf{x}) &= \sum_{\mathbf{z}} p_{\theta}(\mathbf{x}, \mathbf{z}). \end{aligned} \quad (27.7)$$

$\mathbf{W} \in \mathbb{R}^{d_v \times m}$ 连接两组变量, $\mathbf{U}$ 与 $\mathbf{R}$ 分别连接可见组和隐藏组内部, 二者对称且对角线为零; 因子 1/2 避免对同一组内的边重复计数。一般 BM 给定可见变量后, 隐藏变量之间仍可能相互依赖, 所以数据相关的后验期望和不加观测的模型期望都可能需要近似推断。

一种有针对性的限制是删除同组内部的所有边, 即令 $\mathbf{U} = \mathbf{0}$ 、 $\mathbf{R} = \mathbf{0}$ 。**受限玻尔兹曼机** (restricted Boltzmann machine, RBM) 的“受限”指这种二部结构: 给定一组变量, 另一组的节点之间没有剩余相互作用。令 $u_j(\mathbf{x}) = c_j + \sum_i W_{i,j} x_i$, 固定 $\mathbf{x}$ 后,

$$p_{\theta}(\mathbf{z} | \mathbf{x}) = \prod_{j=1}^m \frac{\exp[z_j u_j(\mathbf{x})]}{1 + \exp[u_j(\mathbf{x})]}.$$

每个分母来自对 $z_j = 0, 1$ 的两项求和, 乘积形式直接给出条件独立性。因此

$$\begin{aligned} p_{\theta}(Z_j = 1 | \mathbf{x}) &= \sigma\left(c_j + \sum_i W_{i,j} x_i\right), \\ p_{\theta}(X_i = 1 | \mathbf{z}) &= \sigma\left(b_i + \sum_j W_{i,j} z_j\right). \end{aligned} \quad (27.8)$$

这里没有 Ising 满条件中的系数 2, 原因是当前使用 0/1 编码, 而不是 $\{-1, +1\}$ 。

这项限制还允许一次性消去所有隐藏变量。定义**自由能** (free energy) 为所有隐藏配置的权重之和的负对数, 它是可见配置的有效能量, 而非最

¹ H. Rue, L. Held, *Gaussian Markov Random Fields: Theory and Applications*, Chapman and Hall/CRC, 2005, 1st ed.

优隐藏配置的能量：

$$\begin{aligned}
 F_{\theta}(\mathbf{x}) &:= -\log \sum_{\mathbf{z}} e^{-E_{\theta}(\mathbf{x}, \mathbf{z})} \\
 &= -\mathbf{b}^{\top} \mathbf{x} - \sum_{j=1}^m \log(1 + e^{u_j(\mathbf{x})}), \\
 p_{\theta}(\mathbf{x}) &= \frac{e^{-F_{\theta}(\mathbf{x})}}{Z_{\theta}}.
 \end{aligned} \tag{27.9}$$

推导使用了 $\sum_{\mathbf{z}} \prod_j e^{z_j u_j} = \prod_j (1 + e^{u_j})$ 。一个隐藏节点连接多个可见节点时，相应的 $\log(1 + e^{u_j})$ 通常同时耦合这些可见节点。图 27.2 说明，联合空间里的成对模型，边缘化之后可以产生高阶有效势。




图 27.2 左侧 RBM 只有可见组与隐藏组之间的边；固定任一组，另一组条件独立。右侧消去两个隐藏节点，每个方形因子代表 $1 + \exp[u_j(\mathbf{x})]$ ，均作用于三个可见变量。两侧均省略可见偏置对应的一元势。二部条件独立不等于可见变量边缘独立。

考虑两个可见节点、一个隐藏节点，偏置全为零， $W_{1,1} = W_{2,1} = \log 2$ 。则 $e^{-F(\mathbf{x})} = 1 + 2^{x_1 + x_2}$ ，按 $(0,0), (0,1), (1,0), (1,1)$ 排列的权重为 2, 3, 3, 5，配分函数为 13。给定 $(x_1, x_2) = (1, 1)$ ，隐藏节点为 1 的概率是 4/5；给定 $z = 0$ ，两个可见节点独立且各以 1/2 的概率为 1，给定 $z = 1$ 则各以 2/3 的概率为 1。边缘上却有 $p(X_1 = X_2 = 1) = 5/13$ ，而 $p(X_1 = 1)p(X_2 = 1) = (8/13)^2$ ，二者相差 1/169。

计算一个自由能只需 $O(d_v m)$ 运算，但 $Z_{\theta} = \sum_{\mathbf{x}} e^{-F_{\theta}(\mathbf{x})}$ 一般仍需指数级求和。利用两侧的条件分解，可枚举较小的一组并解析消去另一组，但代价仍含 $2^{\min(d_v, m)}$ 。因此，RBM 解决了给定完整可见向量的隐藏后验计算，没有一般地解决联合归一化；若部分可见变量缺失，求 $p(\mathbf{z} | \mathbf{x}_{\text{obs}})$ 也不再直接是上述独立 Bernoulli 乘积。

二部结构适合**交替 Gibbs 采样** (alternating Gibbs sampling)：轮流固定

一组，独立抽取另一组。算法 27.1 中的抽取必须使用随机二值状态；把概率直接作为下一层的输入会变成另一种迭代，不再是这个 Gibbs 核。

算法 27.1 RBM 的一段交替 Gibbs 链

输入： 固定的有限参数 θ ，初始状态 $\mathbf{x}^{(0)}$ ，步数 $k \geq 1$

输出： 链状态 $\mathbf{x}^{(1)}, \dots, \mathbf{x}^{(k)}$

```

1: for  $t = 0, \dots, k - 1$  do
2:   按式 (27.8) 独立抽取各  $Z_j^{(t+1)}$ 
3:   固定  $\mathbf{z}^{(t+1)}$ ，独立抽取各  $X_i^{(t+1)}$ 
4: end for

```

固定有限参数时，所有条件概率都严格介于 0 与 1，该有限状态链能够到达任意可见配置且存在自转移，并保持 $p_\theta(\mathbf{x})$ 不变。由第 23 章的有限链理论可得长期收敛，但不能据此保证小 k 已充分混合。一次完整更新为 $O(d_v m)$ ；强权重造成的近确定条件分布会使链长时间停留在少数模式。

将第 24 章的潜变量似然梯度实例化到一个权重，单条数据 $\mathbf{x}$ 给出

$$\frac{\partial \log p_\theta(\mathbf{x})}{\partial W_{i,j}} = x_i p_\theta(Z_j = 1 | \mathbf{x}) - \mathbb{E}_{p_\theta}[X_i Z_j]. \quad (27.10)$$

第一项可以精确计算，第二项通常由采样估计。多条记录对第一项取样本平均，偏置更新则使用相应的一阶统计量。RBM 的训练收益来自前一项的简化，不来自后一项的消失。短链重构误差小也不是模型似然高的证据：混合很慢的链可能总能留在起始数据附近，却没有正确表达不同模式之间的概率质量²。

27.2.3 灵活能量模型

二次能量与二值成对能量把相互作用限制在较简单的函数形式中。若数据中的相容关系需要更复杂的非线性特征，可以用神经网络输出一个标量能量。**神经能量模型** (neural energy-based model) 仍由 $p_\theta(\mathbf{x}) \propto e^{-E_\theta(\mathbf{x})}$ 定义，只是用网络参数控制哪些配置具有低能量。网络中的确定性隐藏激活不是自动需要边缘化的随机潜变量；是否存在潜变量，要看概率模型是否为他们定义了分布。

若保留局部分解 $E_\theta(\mathbf{x}) = \sum_C E_{\theta,C}(\mathbf{x}_C)$ ，可以让每个局部网络表示复杂势，同时保留既定图的独立性承诺。若一个网络同时读取所有 x_i 且没有额外分解，它可能形成全局高阶势，不能再仅凭网络内部连接图声称数据变量有稀疏 Markov 结构。神经参数化扩大了函数族，并没有自动带来较低的推断宽度。

连续模型还须控制尾部。一个容易验证的充分条件是

$$E_\theta(\mathbf{x}) = \frac{\alpha}{2} \|\mathbf{x}\|_2^2 + r_\theta(\mathbf{x}), \quad \alpha > 0, \quad r_\theta(\mathbf{x}) \geq -C,$$

² G. Hinton, *A Practical Guide to Training Restricted Boltzmann Machines*, Technical Report UTML TR 2010-003, Version 1, Department of Computer Science, University of Toronto, Aug. 2, 2010

其中 C 有限、能量可测且在正测度集合上有限。此时 $e^{-E_\theta(\mathbf{x})} \leq e^C e^{-\alpha \|\mathbf{x}\|_2^2/2}$, 由高斯积分可知 $0 < Z_\theta < \infty$ 。这是一个充分条件, 不是任意神经网络天然满足的性质。把支持限制在有限体积区域并使能量有适当下界, 也是另一种明确的建模选择。

分类网络的得分则未必定义联合密度。对有限标签集合, 把 $s_k(\mathbf{x})$ 在 k 上做 softmax, 可得 $p(Y = k | \mathbf{x})$; 给所有 s_k 同时加上任意 $c(\mathbf{x})$, 条件概率不变, 但 $\sum_k e^{s_k(\mathbf{x})}$ 会随之改变。因此, 仅有分类训练不能唯一确定输入密度, 更不能直接把某个得分称为 $\log p(\mathbf{x})$ 。采用能量形式时, 必须同时说明支持、归一化对象及训练准则。

神经能量通常没有 RBM 那样的解析块条件分布。在无约束的 $\mathbb{R}^d$ 上, 对连续可微能量可用数据空间梯度驱动采样, 例如 Langevin 离散更新

$$\begin{aligned} \mathbf{x}^{(t+1)} &= \mathbf{x}^{(t)} - \frac{\varepsilon}{2} \nabla_{\mathbf{x}} E_\theta(\mathbf{x}^{(t)}) + \sqrt{\varepsilon} \xi^{(t)}, \\ \xi^{(t)} &\sim \mathcal{N}(\mathbf{0}, \mathbf{I}), \quad \varepsilon > 0. \end{aligned} \quad (27.11)$$

独立高斯噪声让状态不仅沿能量下降, 也能够探索邻近区域。未经 Metropolis 校正的固定步长离散链一般有偏差, 其稳定性还需要对能量梯度施加条件; 有限步链也有初始化与混合误差。若一次能量梯度求值的成本为 C_E , 每条 k 步负样本链的梯度计算成本为 $O(kC_E)$, 不能把一次网络前向传播的成本当作生成一个样本的全部成本。连续神经能量结合梯度采样的具体实现可见 Du 与 Mordatch 的工作, 其有限步训练程序不应被解释为任意能量下的精确采样保证³。

训练时, 对比散度从数据启动短链, 以链终点近似模型期望; 持久链保留上轮状态, 尝试跟踪随参数缓慢变化的模型。这两种做法改变的是模型期望的取得方式, 不保证有限步更新等于精确似然梯度。对神经能量, 偏差还会反过来影响正在学习的能量形状; 训练若只见到某些局部区域的负样本, 其他区域可能出现未被约束的低能量值。上述性质及对比散度并非一般固定目标精确梯度的原因, 见第 24 章。

噪声对比估计不需要每轮运行模型链, 而以已知噪声分布 p_N 构造分类任务; 这里使用的对数比为 $-E_\theta(\mathbf{x}) + c - \log[\nu p_N(\mathbf{x})]$, ν 为噪声与数据样本数量比, c 作为全局归一化参数学习。它不同于随意训练一个数据分类器: 噪声密度和样本比例明确进入目标, 且噪声必须覆盖相关支持。高维噪声若与数据过易区分, 分类信号未必足以精细调整数据附近的密度。

对光滑连续密度, 分数匹配利用 $\nabla_{\mathbf{x}} \log p_\theta = -\nabla_{\mathbf{x}} E_\theta$ 消去配分函数。在式 (24.11) 所说明的可积性与零边界项条件下, 其可优化部分写成

$$\mathbb{E}_{p_*} \left[\frac{1}{2} \|\nabla_{\mathbf{x}} E_\theta(\mathbf{X})\|_2^2 - \Delta_{\mathbf{x}} E_\theta(\mathbf{X}) \right],$$

其中 p_* 是数据分布, $\Delta_{\mathbf{x}}$ 为各坐标二阶偏导之和。代价转向输入导数, 尤

³ Y. Du, I. Mordatch, *Implicit Generation and Modeling with Energy Based Models* In *Advances in Neural Information Processing Systems*, 2019

其是高维 Hessian 迹的计算或估计。标准形式既不直接适用于离散状态，也不能忽略受限支持的边界项；它避免训练时的归一化计算，却没有使最终的 Z 变成已知。结合加噪数据的分数学习将在第 29 章继续讨论。

27.2.4 高阶与关系联合模型

有些约束针对一组节点的整体状态，而非逐对相容性。例如，一组传感器中恰有一个应被激活，或一个逻辑条件同时涉及设备、连接关系和报警。

高阶势 (higher-order potential) 让三个或更多变量共同决定一个局部权重。对二值节点，令 $k_C = \sum_{i \in C} \mathbf{1}\{x_i = +1\}$ ，能量 $g(k_C)$ 可表达计数偏好； $\lambda \mathbf{1}\{k_C \neq k_0\}$ 惩罚计数不等于 k_0 ， $\lambda \mathbf{1}\{0 < k_C < |C|\}$ 则惩罚组内不一致，其中 $\lambda > 0$ 、 $k_0 \in \{0, \dots, |C|\}$ 。

作用域大并不必然意味着存在不可约的高阶相互作用。例如，平方计数代价 $(k_C - k_0)^2$ 展开后只含常数、一元项和成对项。要看真正的区别，可取三个 $\{-1, +1\}$ 变量，令 $p(\mathbf{x}) \propto \exp(\lambda x_1 x_2 x_3)$ ， $\lambda \neq 0$ 。这个模型奖励某种乘积符号，且

$$\sum_{\mathbf{x} \in \{-1, +1\}^3} x_1 x_2 x_3 \log p(\mathbf{x}) = 8\lambda.$$

常数归一化项乘以 $x_1 x_2 x_3$ 求和为零，剩余项为八个 λ 。若同一正分布能够只由这三个变量上的一元和成对势表示，对任一局部对数势，总有一个不在其作用域内的变量，先对该变量求和便得零，因此左侧必须为零，产生矛盾。这证明了该分布不能在不引入额外变量的前提下改写成成对模型；它不排除引入潜变量后的其他表示。

推断的成本取决于高阶势是否还有可利用的代数结构。对 r 个二值变量的任意稠密因子，一张表有 2^r 个条目，向一个变量计算消息一般要遍历其他 2^{r-1} 种配置。纯计数势则可先用动态规划累加其余节点“恰有 k 个为 $+1$ ”的加权总量，再乘上对应的 $e^{-g(k)}$ 求和；单个输出消息的计数卷积可在 $O(r^2)$ 时间内完成。这个局部简化不会消除其他因子引起的全局环。学习时，计数区间的指示量或整体一致性指标替代成对统计量，梯度仍由相应经验值与模型期望之差组成。

当同一种约束要在许多实体上重复使用，逐个手写因子既冗长又容易不一致。**关系模板** (relational template) 规定“哪些类型的实体及关系组成一个因子，以及这些因子共用哪些参数”。把模板中的实体占位符替换为具体对象，称为**落地** (grounding)；得到的仍是普通图模型，但节点和因子可能非常多。参数共享只压缩参数数量，不会使落地实例彼此独立。

Markov 逻辑网络 (Markov logic network, MLN) 把逻辑公式作为这种模板，并按公式成立的落地次数为联合配置计分。为保证对象明确，这里取有限实体域 D 、有限个谓词，不允许产生无限项的函数符号；考虑带有自由实体变量、按所有域元素替换的公式模板。每个落地原子命题对应一

个 Boolean 随机变量, 所有命题真值组成一个配置 $\mathbf{x}$ 。若模板 r 的权重为 w_r 、落地集合为 $\mathcal{I}_r(D)$, 则

$$\begin{aligned} n_r(\mathbf{x}) &= \sum_{g \in \mathcal{I}_r(D)} \mathbf{1}\{\text{公式 } r \text{ 在落地 } g \text{ 上为真}\}, \\ E_\theta(\mathbf{x}) &= - \sum_r w_r n_r(\mathbf{x}), \\ p_\theta(\mathbf{x}) &= Z_\theta^{-1} \exp \left[\sum_r w_r n_r(\mathbf{x}) \right]. \end{aligned} \quad (27.12)$$

公式内部的逻辑蕴含不是有向概率边。正权重表示满足该公式的配置得到奖励, 并不要求每个实例都满足公式; 有限权重下允许矛盾实例以非零概率出现。

例如, $\text{Fault}(a) \Rightarrow \text{Alarm}(a)$ 把同一设备的两种命题联系起来。另一个模板

$$\text{Linked}(a, b) \wedge \text{Fault}(a) \Rightarrow \text{Fault}(b)$$

还涉及不同设备及其连接关系。落地 $(a, b) = (u, v)$ 时, 三个原子命题共同进入一个因子; 若连接关系也是未知变量, 因子便是三阶的。图中两节点相连, 是因为相应命题共同出现在某个落地公式中, 而不是因为两个实体之间必然有物理连接。固定连接证据以后, 因子可能简化, 但这属于对原联合模型的条件化。

权重也不能直接读成规则正确率。只取一个设备的第一个模板, 设 $w = \log 4$ 且没有其他势, 将故障与报警命题的真值分别记为 F, A 。按 $(F, A) = (0, 0), (0, 1), (1, 0), (1, 1)$ 排列, 逻辑蕴含为真的三个配置权重均为 4, 唯一违反配置 $(1, 0)$ 的权重为 1, 所以 $Z = 13$ 。公式成立的概率是 $12/13$, 而 $p(A = 1 \mid F = 1) = 4/5$ 、 $p(A = 1) = 8/13$ 。这些都是同一模型的不同查询, 没有一个可被不加条件地称为权重对应的“规则概率”。引入其他重叠公式以后, 条件概率还会随周围命题的证据改变。

MLN 的似然学习比较观测世界中的 n_r 与模型预期的 n_r , 一个参数的梯度汇总该模板的所有落地实例。完整世界可用伪似然避开联合配分函数; 只观测部分命题时, 数据相关统计量本身也需要后验推断。推断则可以在相关落地图上消元、传递近似消息或采样。含 q 个实体占位符的模板在大小为 $N = |D|$ 的域上可能产生 $O(N^q)$ 个实例, 精确推断还受落地图宽度限制; 不能以模板很短推断计算很轻。MLN 的定义、落地与伪似然学习见 Richardson 和 Domingos 的原始工作⁴。

把规则设为硬约束相当于排除违反配置, 但约束矛盾时可能使 $Z = 0$, 硬约束还可能让单点采样无法穿越不同可行区域。即使全部采用软约束, 扩大实体域也会改变落地次数及不同模板的相对影响; 直接复用权重不保证保留原域中的边缘概率。因此, 关系共享解决的是重复结构的表达与统

⁴ M. Richardson, P. Domingos, *Markov Logic Networks In Machine Learning*, 2006, vol. 62, no. 1–2, pp. 107–136

计合并，不是自动保证跨域规模的概率一致性。

27.3 条件能量模型

在检测任务中，输入常包含温度、历史窗口摘要和传感器类型等已知信息。若只需据此输出一组异常标签，为这些输入建立精确联合分布可能超出了任务所需。条件能量模型固定输入，把表示和计算资源集中到标签之间的相容关系上；它仍需要全局比较输出配置，而不是把每个标签独立分类。

27.3.1 条件随机场的定义

条件随机场（conditional random field, CRF）是给定输入以后、输出变量按照某个无向图满足 Markov 性质的条件分布。实际建模通常直接给出输入相关的团势：

$$\begin{aligned} p_{\theta}(\mathbf{y} | \mathbf{x}) &= \frac{1}{Z_{\theta}(\mathbf{x})} \prod_{C \in \mathcal{C}} \psi_{\theta, C}(\mathbf{y}_C, \mathbf{x}), \\ E_{\theta}(\mathbf{y}, \mathbf{x}) &= - \sum_{C \in \mathcal{C}} \log \psi_{\theta, C}(\mathbf{y}_C, \mathbf{x}). \end{aligned} \quad (27.13)$$

图的节点对应输出变量；在固定输入下，若 S 分离 A 与 B ，则 $\mathbf{Y}_A \perp \mathbf{Y}_B | (\mathbf{Y}_S, \mathbf{x})$ 。输入可以进入多个势，也可以被完整序列编码器处理；只有一个势同时依赖哪些未知标签，才直接决定此处的标签作用域。

对一个既定联合 Markov 网络 $p(\mathbf{x}, \mathbf{y})$ 进行条件化，也会得到这种形式，但这与直接拟合条件分布不是相同的学习任务。联合学习还约束 $p(\mathbf{x})$ ，直接条件学习则没有这项要求。反过来，在给定一个 CRF 后可以另选 $p(\mathbf{x})$ 组成联合分布，但这个额外选择并非 CRF 本身确定。对缺失输入求概率边缘同样需要额外的输入模型，不能直接从 $p(\mathbf{y} | \mathbf{x})$ 中完成。

在常用线性参数化中， $\log \psi_{\theta, C} = \theta^{\top} \mathbf{f}_C(\mathbf{x}, \mathbf{y}_C)$ ，不同作用域可共用参数。对完整标签记录 $\{(\mathbf{x}_r, \mathbf{y}_r)\}_{r=1}^n$ ，条件对数似然为

$$\ell_{\text{cond}}(\theta) = \sum_{r=1}^n \left[\sum_C \theta^{\top} \mathbf{f}_C(\mathbf{x}_r, \mathbf{y}_{r,C}) - \log Z_{\theta}(\mathbf{x}_r) \right]. \quad (27.14)$$

每条输入通常对应不同的配分函数。梯度需要每条输入下的标签边缘，以计算期望特征；精确推断因此既用于预测，也反复出现在训练中。固定特征、完整标签、线性参数化时该对数似然是凹的，但有限最优解的存在仍需考虑可分离性和正则化；使用可训练神经特征或边缘化未观测标签后，不能沿用一般凹性结论。梯度推导见第 24.2.3 节，CRF 的系统表述可参见 Sutton 与 McCallum⁵。

⁵ C. Sutton, A. McCallum, *An Introduction to Conditional Random Fields In Foundations and Trends in Machine Learning*, 2012, vol. 4, no. 4, pp. 267–373

27.3.2 线性链条件随机场

若标签对应按顺序排列的位置，且每个标签只与相邻标签直接相互作用，可以保留链状输出图。**线性链条件随机场** (linear-chain CRF) 把得分拆为状态项和转移项。令序列长度为 T ， $y_t \in \{1, \dots, K\}$ ，有

$$f_{\theta}(\mathbf{y}, \mathbf{x}) = \sum_{t=1}^T a_t(y_t; \mathbf{x}) + \sum_{t=2}^T b_t(y_{t-1}, y_t; \mathbf{x}), \quad (27.15)$$

$$p_{\theta}(\mathbf{y} | \mathbf{x}) \propto e^{f_{\theta}(\mathbf{y}, \mathbf{x})}.$$

a_t 评价输入与当前位置标签的相容性， b_t 评价相邻标签组合；记 $\phi_t(k) = e^{a_t(k; \mathbf{x})}$ 、 $\psi_t(j, k) = e^{b_t(j, k; \mathbf{x})}$ ，参数依赖暂略。始末状态偏好可并入 a_1 和 a_T 。这里的“转移”是相邻标签的势，不要求 $\sum_k \psi_t(j, k) = 1$ ，也不指定因果生成顺序。

链的分解允许把指数多条前缀合并。**前向消息** (forward message) $\alpha_t(k)$ 是所有以 $y_t = k$ 结尾的长度 t 前缀的未归一化权重和。把每个前缀按倒数第二个标签分组，有

$$\alpha_1(k) = \phi_1(k),$$

$$\alpha_t(k) = \phi_t(k) \sum_{j=1}^K \alpha_{t-1}(j) \psi_t(j, k), \quad t = 2, \dots, T, \quad (27.16)$$

$$Z_{\theta}(\mathbf{x}) = \sum_{k=1}^K \alpha_T(k).$$

该递推没有省略任何序列：任一长度 t 的标签前缀恰好属于一个末标签对 (j, k) ，其权重是旧前缀权重乘上新增状态势与边势。对 t 作归纳便证明 α_t 的定义始终成立。

为了计算中间位置的边缘，还需汇总右侧信息。定义 $\beta_t(j)$ 为固定 $y_t = j$ 以后、从 $t+1$ 到 T 的后缀权重和，不含当前位置状态势，则

$$\beta_T(j) = 1,$$

$$\beta_t(j) = \sum_{k=1}^K \psi_{t+1}(j, k) \phi_{t+1}(k) \beta_{t+1}(k), \quad (27.17)$$

$$p(Y_t = k | \mathbf{x}) = \frac{\alpha_t(k) \beta_t(k)}{Z_{\theta}(\mathbf{x})}.$$

固定相邻标签后，左右两段也分别分解，因此

$$p(Y_{t-1} = j, Y_t = k | \mathbf{x}) = \frac{\alpha_{t-1}(j) \psi_t(j, k) \phi_t(k) \beta_t(k)}{Z_{\theta}(\mathbf{x})}. \quad (27.18)$$

状态边缘与边边缘恰好足以计算式 (27.15) 中局部特征的模式期望；求和

消元的通用原理见第 20 章。

现在沿用三位置例子，把未知状态改记为标签 $y_t \in \{-1, +1\}$ 。边势仍在同号时为 3、异号时为 1；某个固定输入给出的状态势，按 $(-1, +1)$ 排列，三个位置分别取 $(1, 2)$ 、 $(1, 1)$ 、 $(1, 3)$ 。输入偏好首尾为正，中间位置没有局部偏好。表 27.1 列出全部配置，使归一化和解码都可直接核验。

状态或标签配置	联合权重 w_0	条件权重 w_x
$(-, -, -)$	9	9
$(-, -, +)$	3	9
$(-, +, -)$	1	1
$(-, +, +)$	3	9
$(+, -, -)$	3	6
$(+, -, +)$	1	6
$(+, +, -)$	3	6
$(+, +, +)$	9	54
总和	32	100

表 27.1 同一组相邻势下的联合与条件权重。符号 +、- 分别表示 +1、-1；条件列在联合列上乘以固定输入给出的三项状态势。两列须分别除以各自总和，不能把状态势误当作已归一化的标签概率。

把两个标签对应的消息值按 $(-1, +1)$ 组成向量，前向递推给出 $\alpha_1 = (1, 2)$ 、 $\alpha_2 = (5, 7)$ 、 $\alpha_3 = (22, 78)$ ，例如 $\alpha_2(+1) = 1(1 \times 1 + 2 \times 3) = 7$ 。因此 $Z(\mathbf{x}) = 100$ 。后向递推给出 $\beta_3 = (1, 1)$ 、 $\beta_2 = (6, 10)$ 、 $\beta_1 = (28, 36)$ ，所以

$$p(Y_2 = +1 | \mathbf{x}) = \frac{7 \times 10}{100} = 0.7.$$

中间位置没有自己的类别偏好，却从两侧输入获得了正类证据。两条边同号的边缘概率都为 0.78；若训练标签是 $(+, +, +)$ ，共享的同号得分参数 $\eta = \log 3$ 在该记录上的似然梯度就是 $2 - 2 \times 0.78 = 0.44$ ，推动模型增加同号序列的相对权重。这里仅实例化期望特征，并未将不同边视为独立训练记录。

如果任务是找最可能的完整标签序列，则应把前向求和换成取最大，并保存前驱。这是 **Viterbi 算法** (Viterbi algorithm)，即在链上复用最优前缀的动态规划。用对数得分避免连乘，有

$$\begin{aligned} \delta_1(k) &= a_1(k; \mathbf{x}), \\ \delta_t(k) &= a_t(k; \mathbf{x}) + \max_j \{\delta_{t-1}(j) + b_t(j, k; \mathbf{x})\}. \end{aligned} \quad (27.19)$$

对每个 (t, k) 保存达到最大值的 j ，从 $\arg \max_k \delta_T(k)$ 向前回溯；平局可按固定标签顺序选择一个最优解。在数值例子中，将 $\exp[\delta_t(k)]$ 按标签 $(-1, +1)$ 排列，三步依次为 $(1, 2)$ 、 $(3, 6)$ 、 $(9, 54)$ ，回溯得到 $(+, +, +)$ ，概率

为 0.54。逐位置选择边缘最大的标签优化的是逐位置错误的期望，不是完整序列概率；本例二者恰好相同，不能据此将两种解码等同。最大积也只适用于这里对全部未知标签的联合最大化；若另有潜变量要先求和，需重新区分联合最优与边缘 MAP。

前向、后向和 Viterbi 各需要 $O(TK^2)$ 时间。仅求配分函数时消息空间为 $O(K)$ ，保留全部节点边缘或解码回溯通常需要 $O(TK)$ 消息或前驱空间；若存储所有稠密边势，另需 $O(TK^2)$ 空间。长序列应使用对数域的 log-sum-exp，或逐步缩放并记录缩放常数，否则数值下溢会破坏归一化。每条训练记录的梯度也需要同量级的前向后向推断，特征提取或神经编码器的成本另计。

输入的远程信息可以进入 a_t ，而不改变上述标签递推；直接加入 y_t 与远处未知标签的耦合则会改变图结构。线性链适合局部标签依赖，但不能独立表达任意长程标签约束。与局部归一化的逐状态分类器相比，CRF 让整个输出序列共同竞争概率质量；代价是每次训练与概率查询都要处理完整链的归一化，而不是分别拟合各个状态的分类概率⁶。

⁶ C. Sutton, A. McCallum, *An Introduction to Conditional Random Fields In Foundations and Trends in Machine Learning*, 2012, vol. 4, no. 4, pp. 267–373

27.3.3 半 Markov 与高阶条件随机场

有些输出对象本来就是片段：一个异常区间的长度、区间内部温度的整体形状，都难以只用相邻标签对评价。**半 Markov 条件随机场** (semi-Markov CRF) 将基本输出单位改为带标签的连续片段，让一个势同时评价片段的起止位置、整体输入及相邻片段标签。它仍对全部合法分段作一次条件归一化，不是先确定边界再各自分类。

设一次分段为 $\mathbf{s} = ((a_\ell, b_\ell, k_\ell))_{\ell=1}^M$ ，片段无重叠、无空隙地覆盖 $1, \dots, T$ ，即 $a_1 = 1$ 、 $a_{\ell+1} = b_\ell + 1$ 、 $b_M = T$ ，长度满足 $1 \leq b_\ell - a_\ell + 1 \leq L$ 。 $k_\ell \in \{1, \dots, K\}$ 是片段标签， M 随分段变化；用 $k_0 = 0$ 表示起始哨兵标签。令 $g(a, b, j, k; \mathbf{x})$ 为前一片段标签 j 接上当前 $[a, b]$ 、标签 k 的得分，则

$$p_\theta(\mathbf{s} | \mathbf{x}) = \frac{\exp\left[\sum_{\ell=1}^M g(a_\ell, b_\ell, k_{\ell-1}, k_\ell; \mathbf{x})\right]}{Z_\theta(\mathbf{x})}. \quad (27.20)$$

配分函数对所有合法 $\mathbf{s}$ 求和，包括不同边界和不同片段数。这里允许相邻片段有相同标签；若任务规定同标签相邻片段必须合并，就应把这项约束写入合法分段集合，算法也要禁止相应转移。

动态规划在片段边界处汇总信息。令 $A_t(k)$ 为覆盖前 t 个位置且末片段标签为 k 的权重和，设 $A_0(0) = 1$ 、 $A_0(k) = 0$ ($k > 0$)，并令 $t > 0$ 时 $A_t(0) = 0$ 。则

$$A_t(k) = \sum_{\ell=1}^{\min(L,t)} \sum_{j=0}^K A_{t-\ell}(j) e^{g(t-\ell+1, t, j, k; \mathbf{x})}. \quad (27.21)$$

仅在首片段允许 $j = 0$ 。递推枚举末片段长度 ℓ 和前一片段标签 j ，每个完整前缀都有唯一的这种拆分，因此没有重复计数；最终 $Z(\mathbf{x}) = \sum_{k=1}^K A_T(k)$ 。将求和改成最大并记录长度和标签，就能回溯最优分段。

学习片段特征还需要片段边缘。记 $B_b(k)$ 为边界 b 之后、前一片段标签固定为 k 的所有后缀权重和，取 $B_T(k) = 1$ ，按下一片段的长度与标签反向递推即可。一次相邻片段连接的边缘概率为

$$\frac{A_{a-1}(j) \exp(a, b, j, k; \mathbf{x}) B_b(k)}{Z_\theta(\mathbf{x})}.$$

这使长度、片段形状及片段转移等特征的期望可计算。若边界与片段标签全部已知，训练使用式 (27.20) 的对数概率；若只给定较粗标签、边界仍未知，分子也须对相容分段求和，不能拿一个最优分段代替这项边缘化。

一个极小例子可以核查“分段”与“逐点标签”的区别。取 $T = 3, K = 1, L = 2$ ，长度 1 片段的权重为 1，长度 2 片段的权重为 2，无其他得分。合法长度序列为 (1, 1, 1), (1, 2), (2, 1)，权重分别为 1, 2, 2。递推得到 $A_1 = 1, A_2 = 3, A_3 = 5$ ，所以配分函数为 5，位置 1 后出现边界的概率为 $(1 + 2)/5 = 3/5$ 。所有分段都给出同一组逐点标签，但边界的不确定性仍然存在；长度上限排除的是一个长度 3 的单片段，不是三个同标签位置组成的序列。

若每个候选片段得分已可常数时间读取，一次前向或后向计算为 $O(TLK^2)$ ，保存全部边界消息需要 $O(TK)$ 空间；预先存储所有含转移的片段得分则可达 $O(TLK^2)$ 。只求配分函数时可以滚动保留最近 L 个边界。若计算片段特征本身需要扫描片段内部，必须额外计入该成本。长度上限降低计算量，也会排除模型本来可能需要的长片段；不能仅因动态规划精确，就忽略候选集合的限制⁷。

另一种扩展不改变逐点输出，而是扩大未知标签的作用域。**高阶条件随机场** (higher-order CRF) 可以用 $(r + 1)$ 个连续标签共同决定一个势，即 $E = -\sum_t f_t(y_{t-r}, \dots, y_t; \mathbf{x})$ ，序列起点使用固定哨兵补齐。在这种有限记忆结构下，消息需保留最近 r 个标签；每个位置有 K^r 种历史，每种历史接上 K 种新标签，所以朴素精确递推为 $O(TK^{r+1})$ 时间、 $O(K^r)$ 滚动消息空间。扩展状态间只能按共享后缀相接，不必建立任意 $K^r \times K^r$ 稠密转移表。

图 27.3 比较了这两种扩展。片段模型通过增加可选长度来表达持续区间；高阶链通过增加消息保留的标签组合来表达更长依赖。二者还可以组合，神经网络也可以参数化其中的局部得分，但其成本不能只用“一阶链”或“神经网络”的名称判断。若高阶势跨越任意远的未知标签，有限记忆递推也未必仍然适用。

⁷ S. Sarawagi, W. W. Cohen, *Semi-Markov Conditional Random Fields for Information Extraction* In *Advances in Neural Information Processing Systems*, 2004




图 27.3 输出作用域的三种选择。一阶链的切分处只需保留一个标签；二阶链中，跨切分处的三元势需要保留两个标签。半 Markov 模型按片段边界递推，图中展示一种 [1, 2] 与 [3, 4] 的分段，推断时还须对其他合法边界求和。

27.3.4 一般图与关系条件随机场

当输出对应二维检测网格，或分别属于存在连接关系的设备时，一条链无法保留所有必要相互作用。一般图 CRF 仍按式 (27.13) 分解，但图由输出之间的关系决定。关系 CRF 进一步将这些作用域写成模板：已知设备属性、连接关系和图结构都进入输入，未知量则是待预测的标签。

例如，给每个设备一个标签 Y_i ，让设备属性产生一元势，让每条已知连接复用同一个相邻标签势。更一般地，若输入 $\mathbf{x}$ 决定模板 r 的实例集合 $\mathcal{I}_r(\mathbf{x})$ ，可写

$$E_{\theta}(\mathbf{y}, \mathbf{x}) = - \sum_r \sum_{g \in \mathcal{I}_r(\mathbf{x})} \theta_r^T \mathbf{f}_r(\mathbf{x}_g, \mathbf{y}_g). \quad (27.22)$$

这里 g 标识一组具体实体及关系所选出的作用域， $\mathbf{x}_g$ 是相关已知特征， $\mathbf{y}_g$ 是参与该因子的未知标签。同一个 θ_r 从全部实例汇总学习信号；不同实例可以重叠，不因此成为独立样本。Taskar 等人的关系 Markov 网络工作给出了这类条件建模与集体分类的代表形式⁸。

固定关系输入并没有自动使输出图无环。例如设备之间的连接形成一个闭环，标签势也会形成闭环。精确推断可以用第 21 章的团树方法，复杂度由消元后的最大作用域决定。若每个标签有 K 种取值、所选消元序的诱导宽度为 w ，主要运算一般含 K^{w+1} ；简单环仍有较小宽度，并非出现一个环就必须近似。密集跨设备约束或大型高阶势则可能使团树不再可承受。

计算受限时，可以用第 22 章的平均场、环置信传播或最大化松弛，也

⁸ B. Taskar, P. Abbeel, D. Koller, *Discriminative Probabilistic Models for Relational Data* In Proceedings of the Eighteenth Conference on Uncertainty in Artificial Intelligence, 2002, pp. 485–492

可以用第 23 章的采样。需要标签概率或条件似然梯度时，目标是边缘和期望；只需要完整标签的最优配置时，目标是最大化得分。对后者有效的图割或整数优化程序，不一定能返回前者。一般图上的环消息可能不收敛，即使收敛也不一般等于精确边缘；用其结果训练时，应明确正在使用近似梯度或近似配分函数。

关系模型还会放大建模假设的影响。若所有连接都被解释为“标签应相同”，实际连接却经常跨越不同故障类型，集体推断会把偏差传播到多个节点。度较大的节点参与更多势，局部错误也可能被多次计入；这需要在特征和参数共享方式上处理，不能靠扩大消息迭代次数修正。已知连接只是输入时，模型也没有定义未知连接的生成概率，不能直接把标签推断扩展成连接生成。

训练与评价应以任务中的完整关系结构为单位说明数据来源。在同一张大图上划分已标注与未标注节点可以构成合法的传导预测任务，但它不同于预测全新独立图；测试标签不得通过邻域特征进入训练。若只观测部分训练标签，需在条件似然分子中对其他标签求和，又会带来后验推断和通常非凹的优化。关系共享有助于合并重复模式的信息，不消除相关性、推断误差或划分泄漏。

27.4 模型比较

这些模型都把局部得分组合成全局概率，差别应落实到哪些变量参与归一化、哪些变量被观测，以及积分或求和能否利用结构。表 27.2 列出本章所讨论的代表设定；同一实例可以同时具有多行中的属性，例如神经高阶关系 CRF 仍然属于条件能量模型，不能把表中名称当作互斥分类。

联合与条件的选择主要由查询决定。若需要解释整组测量、补全不同类型的未知变量或生成新的联合配置，就需要相应联合模型；若始终固定输入，只评价标签预测，直接条件建模避免额外约束输入分布。条件化不等于局部归一化，也不保证计算更便宜：一个复杂的输出图仍可能难以求和，而且训练中每个不同输入都有自己的 $Z_{\theta}(\mathbf{x})$ 。

表示能力与计算代价也不能只靠“势是否成对”判断。GMRF 即使有环也能借助二次结构计算，RBM 即使只有成对边也可能难以归一化；计数高阶势可以利用卷积，任意高阶表却要付出指数存储。神经网络扩大局部函数族时可以保持原图，直接给全局配置打分则可能失去稀疏分解。真正相关的是运算的代数形式、未知变量作用域和消元后的宽度。

学习的主要障碍与这些推断结构对应。完整离散联合模型需要模型期望；BM 还需要数据条件下的隐藏后验，RBM 只简化了后者；连续神经能量常把计算预算花在生成负样本或求输入导数上。链式 CRF 虽可精确求期望，长序列、大标签集和大量样本仍使反复推断昂贵。判断一套训练流

代表设定	归一化对象	变量与潜变量	势的作用域	可计算性与主要限制
Ising / Potts	全部状态	离散; 此处全观测	一元、成对	树上精确; 一般图的全局求和与强耦合采样可能昂贵
高斯 MRF	全部状态	连续; 此处全观测	二次能量	正定精度下可解析归一化; 矩阵填充与单峰限制
BM / RBM	可见与隐藏状态	二值; 含潜变量	联合空间成对	RBM 的块条件与自由能可算, 联合配分函数一般仍难
神经联合能量	全部状态	可离散或连续; 潜变量可选	局部或全局	网络求值不等于归一化; 尾部、采样和学习偏差均需控制
MLN	落地命题配置	Boolean; 可有未观测命题	模板决定阶数	参数共享不消除落地数量及推断宽度的增长
线性链 CRF	给定输入的标签	离散; 此处完整标签	一元、相邻成对	$O(TK^2)$ 精确归一化; 不直接表示任意远程标签约束
半 Markov / 高阶链 CRF	分段或标签组合	离散; 边界可未观测	片段或连续高阶	分别受 L 与 K' 影响; 有限结构下可精确递推
一般图关系 CRF	给定关系输入的标签	此处离散; 标签可缺失	成对或高阶	低宽度可精确; 宽图依赖近似推断且须重复用于学习

表 27.2 按本章具体设定比较模型。 T 为序列长度, K 为标签数, L 为最大片段长度, r 为高阶链保留的历史标签数。潜变量、势阶数与参数化方式可以组合; 条件无向模型也可以有连续输出, 此表不穷尽这些组合。

程时, 应分别检查能量是否定义了合法分布、所需查询能否求出, 以及近似训练究竟偏离了什么目标; 这些问题不能用一个训练损失数值代替。

27.5 本章小结

局部相容信息之所以能成为整组状态的概率, 是因为所有配置的权重共同参与归一化。能量只是这些权重的负对数表示; 绝对能量零点可以改变, 状态之间的能量差以及归一化后的概率才决定模型行为。三位置例子中, 未加输入时的配分函数为 32; 固定新的输入相关状态势后, 标签配分函数变成 100, 中间位置即使没有自己的偏好, 也会通过相邻作用获得两侧证据。

联合无向模型与条件无向模型区分的是求和对象, 不是势是否复杂。引入潜变量可以把简单联合相互作用转成复杂边缘依赖, RBM 的二部结构使隐藏后验和自由能可算, 却未消除联合归一化。高阶势与关系模板可以表达整体约束, 但须检查作用域、落地规模与硬约束的可行性。神经能量允许更灵活的函数形状, 也需要单独保证可归一化并控制采样或替代学习准则的误差。

条件能量模型把输入视为给定, 并不削弱对输出依赖的建模。链、片段和有限阶历史之所以可精确计算, 是因为递推只需保留有限边界信息; 一般输出图则仍受推断宽度限制。由此回到开篇的问题: 是否需要解释测量的生成分布, 决定选用联合无向模型还是条件无向模型; 需要保留何种相互作用, 以及能承受哪种求和或采样代价, 决定其内部结构。模型选择、推断与参数学习必须在这两个层次上相互配合。

同样是序列结构，也可以先描述潜状态怎样演化，再描述观测怎样产生。第 28 章采用这一有向生成方式，继续使用链上的求和与最大化，但其局部因子是转移、发射分布，而非给定完整输入后的任意标签势。这一区别决定了模型能否直接预测未来观测。

动态有向模型与状态空间模型

一台设备连续两次报警，与只在某个时刻报警，提供的信息并不相同。设备状态通常不会在相邻时刻完全重置，传感器却可能偶尔误报。要判断设备现在是否异常，需要把历史判断和新观测合起来；要事后追查故障从何时开始，还需要让后来的证据反过来修正早先的判断。这里的核心问题是：怎样表示随时间演化的不确定性，又怎样避免每收到一个观测就从头处理整个历史？

第 17 章的有向分解给出模型的组织方式，第 20 章与第 21 章的消元和消息传递给出计算基础。本章把这些工具放到时间轴上：共同表示说明哪些信息必须跨时刻传递，离散状态与连续状态则决定传递的信息能否用有限概率表或高斯参数精确保存。状态不可见时，推断得到的后验统计量又会成为参数学习的输入。

本章的时间可以是物理采样时刻，也可以是有明确前后关系的序列位置；它描述任务或系统本身的状态演化。第 27 章的序列条件随机场直接建模给定观测后的标签分布；它虽然也利用序列结构，关注的却是条件预测，而非任务或系统状态本身的演化。第 29 章的扩散模型沿人为设定的噪声过程构造生成分布，其时间含义也与设备运行时间不同。

28.1 动态有向模型的共同形式

若把每个时刻的依赖都画成一张独立的有向图，就会重复大量相同结构。**动态有向图模型**（dynamic Bayesian network, DBN）用一个可重复展开的有向图模板描述序列中的依赖：同一时刻内部可以有依赖，相邻时刻之间也可以有依赖。它是组织动态模型的共同表示，不是与隐马尔可夫模型、状态空间模型并列的另一种特定分布。

设第 t 个**时间切片**（time slice）包含随机向量 $\mathbf{Y}_t = (Y_{t,1}, \dots, Y_{t,d})^\top$ ，即在同一时刻需要描述的 d 个变量，其中一些可见，另一些隐藏。为简化表

示, 先假设跨切片的边只从 $t-1$ 指向 t 。令 $\text{pa}^-(i)$ 表示上一切片中指向当前节点 i 的节点索引集, $\text{pa}^0(i)$ 表示当前切片内部的父节点索引集, 则转移模板写成

$$p(\mathbf{y}_t | \mathbf{y}_{t-1}) = \prod_{i=1}^d p(y_{t,i} | \mathbf{y}_{t-1, \text{pa}^-(i)}, \mathbf{y}_{t, \text{pa}^0(i)}). \quad (28.1)$$

切片内的图必须无环。按时间排序, 再按每个切片内部的拓扑序排序, 就得到展开图的拓扑序, 因此任意有限长度 T 的展开都是有向图。初始切片需要另给分布 $p(\mathbf{y}_1)$; 只有转移模板还不能确定整条序列的分布。**两切片动态有向图模型** (two-slice temporal Bayesian network, 2TBN) 描述的正式 (28.1) 中的这段重复结构。

最常用的简化是把所有影响未来的内部信息集中为潜状态 $\mathbf{z}_t$, 并用 $\mathbf{x}_t$ 表示观测。状态是模型为了描述未来而保留的变量, 不一定等于某个直接可测的物理量。假设给定 $\mathbf{z}_{t-1}$ 后, $\mathbf{z}_t$ 不再依赖更早的状态; 给定全部状态后, 各时刻观测条件独立, 且 $\mathbf{x}_t$ 只依赖 $\mathbf{z}_t$ 。由此得到**状态空间模型** (state space model, SSM), 即用状态转移与观测产生两个局部机制描述序列:

$$\begin{aligned} p(\mathbf{z}_{1:T}, \mathbf{x}_{1:T}) &= p(\mathbf{z}_1) p(\mathbf{x}_1 | \mathbf{z}_1) \\ &\times \prod_{t=2}^T p(\mathbf{z}_t | \mathbf{z}_{t-1}) p(\mathbf{x}_t | \mathbf{z}_t). \end{aligned} \quad (28.2)$$

这与第 23.4 节为粒子滤波引入的联合分解相同, 仍以 $\mathbf{z}_t$ 表示潜状态、 $\mathbf{x}_t$ 表示观测; 本章进一步研究哪些分布能精确递推, 以及怎样学习转移和观测参数。本章用 p 统一表示概率质量函数或相对于相应测度的密度; 离散状态下的积分应改成求和。小写粗体在分布表达式中表示状态与观测向量, 标量离散模型则明确使用随机变量 Z_t, X_t 及其取值 z_t, x_t 。图 28.1 把这一模板展开为三个时刻; 每个潜状态承担两种作用, 一种是影响当前观测, 另一种是向未来传递信息。一般 DBN 还可以包含观测间的边或更复杂的切片内依赖, 因而式 (28.2) 只是它的重要特例。




图 28.1 状态空间模型的有限展开。空心节点表示潜状态, 填色节点表示观测; 竖直虚线区分时间切片。消去过去后, 当前潜状态上的后验分布是继续预测所需的信息, 图中箭头表示生成依赖而不是推断只能进行的方向。

“只依赖上一步”与“过程没有长期记忆”不能画等号。**Markov 假设** (Markov assumption) 约束的是给定所选状态后的条件分布；状态本身可以包含历史。若原始状态满足 r 阶依赖 $p(\mathbf{z}_t | \mathbf{z}_{t-r:t-1})$ ，把最近 r 个状态拼成扩充状态，就能改写为一阶模型，但状态空间随之扩大。观测过程也未必是一阶 Markov 过程，因为观测只间接反映状态，整个观测历史仍可能改变当前状态的后验。

另一组容易混淆的条件是转移机制不变与分布不变。**时间齐次性** (time homogeneity) 要求转移核不随 t 改变；**参数共享** (parameter sharing) 要求多个位置复用同一组参数，既可以作用于转移，也可以作用于观测。即使共享参数，若条件分布还显式依赖时间或已知外部输入，其数值也未必时间齐次。**严格平稳性** (strict stationarity) 则要求任意有限组时刻的联合分布在整体平移后不变。齐次 Markov 链还需要从平稳分布初始化，才能得到平稳过程。例如，每次都按同一个规则升温的设备仍可从冷启动逐渐进入热状态，其转移参数不变，边缘分布却在变化。

序列能够递推处理，原因不只是图画成了一条链，而是过去与未来之间存在有限的**时间接口** (temporal interface)：在一个时间分界处，所有跨界依赖必须经过的变量集合。对一阶状态空间模型，给定 $\mathbf{z}_t$ 即可分开更早的变量与未来变量。对一般 DBN，可取当前切片中具有下一切片子节点的变量作为接口，并在消元时保留它们的联合分布。接口包含多个变量时，只保存各自边缘通常不够，因为过去证据可能使它们相关。离散接口的联合状态数、连续接口的后验表达形式，才是递推是否廉价的关键；这与第 20 章的诱导宽度问题一致。DBN 的图模板、接口与精确推断之间的关系可参见 Koller 和 Friedman 的论述¹。

在同一个模型上，不同任务使用的证据范围不同。**预测** (prediction) 计算 $p(\mathbf{z}_{t+h} | \mathbf{x}_{1:t})$ 或 $p(\mathbf{x}_{t+h} | \mathbf{x}_{1:t})$ ，其中 $h \geq 1$ ；它回答尚未观测的未来可能怎样。**滤波** (filtering) 计算 $p(\mathbf{z}_t | \mathbf{x}_{1:t})$ ，只用当前及过去的信息判断当前状态。**平滑** (smoothing) 计算 $p(\mathbf{z}_t | \mathbf{x}_{1:T})$ ，其中 $t < T$ ，允许后来的观测修正早先的判断。固定间隔平滑在长度为 T 的整段数据上工作，固定滞后平滑则只等待预定的若干步未来观测。

若任务必须输出一条完整解释，还可以求**最可能状态序列** (most probable state sequence)，即最大化 $p(\mathbf{z}_{1:T} | \mathbf{x}_{1:T})$ 的整条路径。所有潜状态都被最大化时，这是第 20 章的 MPE 查询；若只最大化部分状态而对其余状态积分或求和，则变成边缘 MAP 问题。逐时刻选择平滑边缘中概率最大的状态，优化的是各位置的错误数，不一般等于整条路径的联合最优解。连续状态下最大化的是所选坐标与基准测度下的后验密度，而不是某一点的正概率。

这些查询共享同一个递推起点。记 $f_{t-1}(\mathbf{z}_{t-1}) = p(\mathbf{z}_{t-1} | \mathbf{x}_{1:t-1})$ ，先对

¹ D. Koller, N. Friedman, *Probabilistic Graphical Models: Principles and Techniques*, MIT Press, 2009

旧状态边缘化，再用当前观测做 Bayes 更新，得到

$$\begin{aligned} f_t^-(\mathbf{z}_t) &= \int p(\mathbf{z}_t | \mathbf{z}_{t-1}) f_{t-1}(\mathbf{z}_{t-1}) d\mathbf{z}_{t-1}, \\ c_t &= \int p(\mathbf{x}_t | \mathbf{z}_t) f_t^-(\mathbf{z}_t) d\mathbf{z}_t, \\ f_t(\mathbf{z}_t) &= \frac{p(\mathbf{x}_t | \mathbf{z}_t) f_t^-(\mathbf{z}_t)}{c_t}. \end{aligned} \quad (28.3)$$

初始化为 $f_1^- = p(\mathbf{z}_1)$ ，且要求每个 c_t 有限并大于零。这里 $c_t = p(\mathbf{x}_t | \mathbf{x}_{1:t-1})$ 是一步预测观测的概率或密度，所以 $\log p(\mathbf{x}_{1:T}) = \sum_{t=1}^T \log c_t$ 。递推不仅给出状态后验，也直接给出训练与模型比较所需的观测似然。接下来的模型差别，正是这些积分能否精确计算，以及计算结果是否仍能用固定大小的对象表示。

28.2 离散状态演化模型

先考虑状态可以直接读出的设备，例如每次巡检都能可靠记录设备处于正常或异常状态。令 $Z_t \in \{1, \dots, K\}$ ，初始概率为 $\pi_i = p(Z_1 = i)$ ，齐次转移矩阵 $\mathbf{A} \in \mathbb{R}^{K \times K}$ 的元素为

$$a_{i,j} = p(Z_t = j | Z_{t-1} = i), \quad a_{i,j} \geq 0, \quad \sum_{j=1}^K a_{i,j} = 1.$$

每一行描述从一个当前状态出发，下一时刻如何分配概率。满足 $p(\mathbf{z}_t | \mathbf{z}_{1:t-1}) = p(\mathbf{z}_t | \mathbf{z}_{t-1})$ 的过程称为 **Markov 链** (Markov chain)。本节先讨论有限状态、离散时间、齐次的情形，初始概率向量 $\boldsymbol{\pi}$ 取列向量形式。

令 $\mathbf{q}_t$ 为 Z_t 的概率列向量，对中间状态求和便得到 $\mathbf{q}_{t+1} = \mathbf{A}^\top \mathbf{q}_t$ ；反复应用这一关系得到

$$\mathbf{q}_{t+h} = (\mathbf{A}^\top)^h \mathbf{q}_t, \quad p(Z_{t+h} = j | Z_t = i) = (\mathbf{A}^h)_{i,j}. \quad (28.4)$$

矩阵幂并不是额外的概率假设：两步转移的元素 $\sum_k a_{i,k} a_{k,j}$ 枚举了所有中间状态， h 步形式由归纳得到。

示例 28.1 两状态设备的多步预测 以下另设一组人工教学参数，状态 1 表示正常，状态 2 表示异常。这不是四节点报警模型的时间展开；与例 23.2 相比，状态编号和初始分布也不同，后面的发射参数将独立给定：

$$\boldsymbol{\pi} = \begin{pmatrix} 0.8 \\ 0.2 \end{pmatrix}, \quad \mathbf{A} = \begin{pmatrix} 0.9 & 0.1 \\ 0.2 & 0.8 \end{pmatrix}.$$

若当前确定正常，下一步异常概率为 0.1，两步后异常概率为 $0.9 \times$

$0.1 + 0.1 \times 0.8 = 0.17$ 。若当前异常概率为 u_t ，则

$$u_{t+1} = 0.1(1 - u_t) + 0.8u_t = 0.1 + 0.7u_t.$$

因而 $u_{t+h} = 1/3 + 0.7^h(u_t - 1/3)$ 。初始信息随预测步数增加逐渐减弱，异常概率趋向 $1/3$ ，并不趋向转移矩阵中的任意单个元素。

不随转移改变的分布 π_* 称为**平稳分布** (stationary distribution)，满足 $\mathbf{A}^\top \pi_* = \pi_*$ 且分量非负、总和为 1。例 28.1 中，它是 $(2/3, 1/3)^\top$ 。有限链若**不可约** (irreducible)，即任意两个状态之间都有正概率的有限步路径，则平稳分布唯一；再加**非周期性** (aperiodicity)，即返回某状态的可能步数的最大公约数为 1，从任意初始分布出发的 $\mathbf{q}_t$ 都会收敛到 π_* 。这里的**遍历性** (ergodicity) 需要结合所指结论理解：有限不可约链的时间平均满足遍历大数定律，而逐步分布收敛还需要排除周期。

这一条件差别可以直接检验。转移矩阵 $\begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}$ 具有唯一平稳分布 $(1/2, 1/2)^\top$ ，但从状态 1 开始，逐步分布一直交替，不能收敛；每个状态的长期出现频率却趋向 $1/2$ 。若 $\mathbf{A}$ 为单位矩阵，各状态均吸收，平稳分布又不唯一。一般有限链结论来自不可约随机矩阵的谱与遍历理论，第 23 章已在 Markov 链采样背景下说明相关条件；本章不把它们推广为任意连续状态过程的无条件结论。

状态全部可见时，参数学习退化为计数。令 $n_{i,j}$ 为训练序列中 $i \rightarrow j$ 的转移次数，观测序列的转移对数似然为 $\sum_{i,j} n_{i,j} \log a_{i,j}$ 。在每行总和为 1 的约束下求极值得到 $\hat{a}_{i,j} = n_{i,j} / \sum_k n_{i,k}$ 。若一行从未被访问，这一行不能由数据估计；可使用先验或保留原值，但不能把 $0/0$ 当成估计。多条独立序列应各自计数，不能把一条序列的结尾与另一条的开头当作真实转移。初始分布同样由各序列首状态估计，而非由全部状态出现频率估计。

实际设备的内部状态通常不可直接读取，只能看到报警或温度等输出。为此，在 Markov 链下方加入观测层：**隐马尔可夫模型** (hidden Markov model, HMM) 用一个不可见的有限状态链生成观测，每个状态拥有自己的**发射分布** (emission distribution)，即该状态下会产生哪些观测。记 $b_j(x) = p(x | Z_t = j)$ 为该条件分布在 x 处的概率质量或密度，则

$$p(z_{1:T}, x_{1:T}) = \pi_{z_1} b_{z_1}(x_1) \prod_{t=2}^T a_{z_{t-1}, z_t} b_{z_t}(x_t). \quad (28.5)$$

“离散”限定的是隐藏状态，不要求观测离散：报警可以用 Bernoulli 分布，温度可以用状态相关的高斯密度。对照第 26 章的混合模型，HMM 增加的是相邻潜类别之间的依赖；各时刻不再独立抽取混合成分。

若枚举全部状态路径，求 $p(x_{1:T})$ 需要处理 K^T 个配置。链式分解允

许把所有具有同一末状态的前缀合并。定义未归一化前向消息 $\alpha_t(j) = p(x_{1:t}, Z_t = j)$, 从

$$\alpha_t(j) = b_j(x_t) \sum_i p(x_{1:t-1}, Z_{t-1} = i) a_{i,j}$$

得到递推

$$\begin{aligned} \alpha_1(j) &= \pi_j b_j(x_1), \\ \alpha_t(j) &= b_j(x_t) \sum_{i=1}^K \alpha_{t-1}(i) a_{i,j}, \\ p(x_{1:T}) &= \sum_j \alpha_T(j). \end{aligned} \quad (28.6)$$

推导中的求和消去了 Z_{t-1} , 而更早状态已经包含在 α_{t-1} 中。初始式直接成立, 递推式保持 α_t 的概率含义, 因此也给出了算法正确性的归纳论证。滤波概率就是 $\alpha_t(j) / \sum_i \alpha_t(i)$ 。

事后判断早期状态还需要把未来观测的影响传回来。定义后向消息 $\beta_t(i) = p(x_{t+1:T} | Z_t = i)$; 未来为空时 $\beta_T(i) = 1$ 。对下一状态求和得到

$$\begin{aligned} \beta_t(i) &= \sum_{j=1}^K a_{i,j} b_j(x_{t+1}) \beta_{t+1}(j), \\ \gamma_t(i) &:= p(Z_t = i | x_{1:T}) = \frac{\alpha_t(i) \beta_t(i)}{L}, \\ \xi_t(i, j) &:= p(Z_t = i, Z_{t+1} = j | x_{1:T}) \\ &= \frac{\alpha_t(i) a_{i,j} b_j(x_{t+1}) \beta_{t+1}(j)}{L}, \end{aligned} \quad (28.7)$$

其中 $L = p(x_{1:T}) > 0$ 。给定 Z_t 后, 过去观测与未来观测条件独立, 所以 $\alpha_t \beta_t$ 恰好组合了互不重叠的两部分证据。这就是**前向-后向算法** (forward-backward algorithm): 前向消去过去, 后向压缩未来, 再在目标时刻相遇。 γ_t 适合单时刻平滑, ξ_t 保留相邻状态的联合后验, 是学习转移参数所需的量。

长序列直接相乘容易数值下溢。可每步归一化, 令 $\hat{\alpha}_t(j) = p(Z_t = j | x_{1:t})$, 以未归一化更新的总和作为 c_t 。后向也要匹配这一缩放: 取 $\hat{\beta}_T = 1$, 递推时将 $\sum_j a_{i,j} b_j(x_{t+1}) \hat{\beta}_{t+1}(j)$ 除以 c_{t+1} 。于是 $\gamma_t(i) = \hat{\alpha}_t(i) \hat{\beta}_t(i)$, 而 ξ_t 的缩放分母为 c_{t+1} 。也可在对数域使用稳定的对数求和计算。若 $c_t = 0$, 模型认为当前观测前缀不可能, 此时不能继续除法, 更不能任意均匀后验掩盖模型与数据的冲突。

算法 28.1 缩放的 HMM 前向-后向递推

输入： π, A, b_j 与观测 $x_{1:T}$, $T \geq 1$
输出： 似然对数、平滑概率 γ_t 与成对概率 ξ_t

- 1: $u_1(j) \leftarrow \pi_j b_j(x_1)$, $c_1 \leftarrow \sum_j u_1(j)$
- 2: 若 $c_1 = 0$, 报告观测不在模型支撑内并终止
- 3: $\hat{\alpha}_1(j) \leftarrow u_1(j)/c_1$
- 4: **for** $t = 2, \dots, T$ **do**
- 5: $u_t(j) \leftarrow b_j(x_t) \sum_i \hat{\alpha}_{t-1}(i) a_{i,j}$
- 6: $c_t \leftarrow \sum_j u_t(j)$; 若 $c_t = 0$ 则报告并终止
- 7: $\hat{\alpha}_t(j) \leftarrow u_t(j)/c_t$
- 8: **end for**
- 9: $\hat{\beta}_T(i) \leftarrow 1$, $\gamma_T(i) \leftarrow \hat{\alpha}_T(i)$
- 10: **for** $t = T-1, \dots, 1$ **do**
- 11: $\hat{\beta}_t(i) \leftarrow \sum_j a_{i,j} b_j(x_{t+1}) \hat{\beta}_{t+1}(j)/c_{t+1}$
- 12: $\gamma_t(i) \leftarrow \hat{\alpha}_t(i) \hat{\beta}_t(i)$
- 13: $\xi_t(i, j) \leftarrow \hat{\alpha}_t(i) a_{i,j} b_j(x_{t+1}) \hat{\beta}_{t+1}(j)/c_{t+1}$
- 14: **end for**
- 15: 返回 $\sum_t \log c_t$ 及上述后验统计量

算法 28.1 对密集转移矩阵的时间复杂度为 $O(TK^2)$, 另加发射概率求值成本。只做在线滤波时, 消息工作内存为 $O(K)$; 保存全部前向消息再做平滑需 $O(TK)$ 内存。若只为 EM 累计转移计数, ξ_t 可以边算边累加, 无须保存 T 张 $K \times K$ 表。稀疏转移可以只遍历允许的边, 但状态数增大仍会增加代价。

示例 28.2 报警证据怎样改变过去的判断 沿用例 28.1 的 π 和 A , 令 $X_t = 1$ 表示报警, 设 $b_1(1) = 0.1$ 、 $b_2(1) = 0.7$ 。这两个概率同样只是教学设定。对观测 $x_{1:3} = (0, 1, 1)$, 前向消息依次为

$$\begin{aligned}\alpha_1 &= (0.72, 0.06)^\top, \\ \alpha_2 &= (0.066, 0.084)^\top, \\ \alpha_3 &= (0.00762, 0.05166)^\top.\end{aligned}$$

例如第二步正常状态的权重为 $(0.72 \times 0.9 + 0.06 \times 0.2) \times 0.1 = 0.066$ 。总似然为 0.05928; 后向消息为 $\beta_3 = (1, 1)^\top$ 、 $\beta_2 = (0.16, 0.58)^\top$ 和 $\beta_1 = (0.055, 0.328)^\top$ 。因此, 第一个时刻的异常滤波概率为 $0.06/0.78 \approx 0.0769$, 异常平滑概率却为 $0.06 \times 0.328/0.05928 \approx 0.3320$ 。后来的连续报警, 使“此前已经异常但暂未报警”成为更可信的解释。

表 28.1 汇总同一组数据上的判断。平滑利用更多证据, 不保证每次都把某个指定状态的概率推向同一方向; 本例的方向来自两次报警与异常状态的较高持续概率。

时刻 t	报警 x_t	异常滤波概率	异常平滑概率
1	0	0.076923	0.331984
2	1	0.560000	0.821862
3	1	0.871457	0.871457

表 28.1 人工设备模型的后验比较。滤波列只使用截至该时刻的观测，平滑列均使用 $x_{1:3}$ ；末时刻两者相同。

若需要整条路径的联合最优解，把前向递推中的求和替换成最大值还不够，还要记录每次最大值来自哪个前驱。定义 $\delta_t(j)$ 为所有以 j 结尾的路径中最大的联合概率 $p(z_{1:t}, x_{1:t})$ ，得到**Viterbi 算法** (Viterbi algorithm)，它保留每个末状态下的最优前缀：

$$\begin{aligned}\delta_1(j) &= \pi_j b_j(x_1), \\ \delta_t(j) &= b_j(x_t) \max_i \{\delta_{t-1}(i) a_{i,j}\}, \\ \psi_t(j) &\in \arg \max_i \{\delta_{t-1}(i) a_{i,j}\}.\end{aligned}\quad (28.8)$$

选 $z_T^* \in \arg \max_j \delta_T(j)$ ，再按 $z_t^* = \psi_{t+1}(z_{t+1}^*)$ 回溯即可。若存在平局，可以固定选择最小状态索引。正确性来自最优子结构：在末状态固定时，后续因子对所有前缀完全相同，替换成更优前缀不会损失未来的最优值。时间复杂度仍为 $O(TK^2)$ ，常规回溯表占 $O(TK)$ ；实现宜使用对数得分并把不允许的转移记为 $-\infty$ 。

对例 28.2, Viterbi 路径为 (1, 2, 2), 联合概率是 $0.8 \times 0.9 \times 0.1 \times 0.7 \times 0.8 \times 0.7 = 0.028224$ ，条件于观测后的路径概率约为 0.4761。这只是所有路径中概率最高的一条，不表示每个时刻都已确定。逐位置最优与路径最优的差别也可用一个两时刻分布检验：设 (1, 1), (1, 2), (2, 1), (2, 2) 的概率分别为 0.40, 0.25, 0.01, 0.34，则第一个位置的边缘最优是 1，第二个是 2，组合 (1, 2) 的概率却低于联合最优 (1, 1)。该分布可由初始分布 (0.65, 0.35) 及对应条件转移实现，因此这一差别确实会发生在 Markov 模型中。

隐藏状态不可见后，直接计数不再可行，但可以用后验期望计数替代实际计数。**Baum-Welch 算法** (Baum-Welch algorithm) 就是 HMM 上的 EM：E 步用前向-后向算法计算当前参数下的 γ_t, ξ_t ，M 步最大化这些软计数给出的期望完全数据对数似然。令当前迭代参数为 $\theta^{(k)}$ ，完全数据对数似然

由初始项、转移项和发射项组成，其条件期望为

$$\begin{aligned} Q(\theta | \theta^{(k)}) = & \sum_i \gamma_1(i) \log \pi_i \\ & + \sum_{t=1}^{T-1} \sum_{i,j} \xi_t(i, j) \log a_{i,j} \\ & + \sum_{t=1}^T \sum_j \gamma_t(j) \log b_j(x_t). \end{aligned} \quad (28.9)$$

右侧后验权重全部用旧参数计算，M 步只改变对数中的候选参数。对 $a_{i,j}$ 加入每行归一化约束，拉格朗日一阶条件给出 $a_{i,j} \propto \sum_t \xi_t(i, j)$ ；利用 $\sum_j \xi_t(i, j) = \gamma_t(i)$ 便得到

$$\begin{aligned} \pi_i^{(k+1)} &= \gamma_1(i), \\ a_{i,j}^{(k+1)} &= \frac{\sum_{t=1}^{T-1} \xi_t(i, j)}{\sum_{t=1}^{T-1} \gamma_t(i)}, \\ b_j^{(k+1)}(v) &= \frac{\sum_{t=1}^T \gamma_t(j) \mathbf{1}\{x_t = v\}}{\sum_{t=1}^T \gamma_t(j)}. \end{aligned} \quad (28.10)$$

最后一行适用于有限字母表上的类别发射。若发射为高斯分布，均值改为 $\sum_t \gamma_t(j) \mathbf{x}_t / \sum_t \gamma_t(j)$ ，协方差改为围绕更新后均值的加权残差二阶矩。多条序列的各项统计量分别计算再相加，初始概率则对各序列的 γ_1 取平均。

本例中， $\xi_1(1, 2) = 0.72 \times 0.1 \times 0.7 \times 0.58 / 0.05928 \approx 0.493117$ ， $\xi_2(1, 2) \approx 0.077935$ 。一次 M 步把 $a_{1,2}$ 更新为 $(0.493117 + 0.077935) / (0.668016 + 0.178138) \approx 0.674880$ ；两个状态的报警概率更新为 0.314642 与 0.836082。短序列上参数变化很大，说明“似然提高”不能代替参数估计可靠性的判断。实际训练通常从多组合理初值开始，以似然相对增量和迭代上限共同停止，并用独立序列或时间上隔离的验证段选择模型。

第 24 章的 EM 单调性结论适用于精确 E 步和提高 Q 的 M 步，但只保证观测似然不下降，不保证全局最优、状态语义正确或测试预测改善。分母为零意味着当前后验从不访问该状态，相应参数无法用该轮软计数确定。正的初始化、结构约束及先验可减少某些退化，但不能使无信息的数据突然识别全部状态。

隐藏状态的编号本身没有意义。同时置换 π 、 $\mathbf{A}$ 的行列及各发射分布，观测似然保持不变，这称为**标签交换** (label switching)，即多个编号方式表示同一个观测模型。相似发射分布还会使不同状态难以区分；若所有状态的发射分布完全相同，且观测只按式 (28.5) 产生，则观测分布甚至不含转移矩阵的信息。状态数 K 因此不能只按训练似然选择：更大的 K 可能把一个状态拆成多个近似副本，或用额外状态补偿持续时间模型的错误。验

证预测似然、可解释的持续时间和足够的状态占用，比单看训练分数更有帮助；潜变量模型的常规信息准则还受到奇异性与可识别性条件的限制。HMM 的推断、学习及模型选择可结合 Murphy 的教材进一步阅读²。

² K. P. Murphy, *Machine Learning: A Probabilistic Perspective*, MIT Press, 2012

HMM 的扩展可以按究竟放宽了什么假设来理解。如果下一状态确实依赖最近 r 个状态，就得到**高阶 HMM** (higher-order HMM)。将 $(Z_{t-r+1}, \dots, Z_t)$ 作为新状态可继续使用动态规划。每个扩充状态只有 K 个合法后继，利用移位结构时转移计算为 $O(TK^{r+1})$ ，而不是把 K^r 个扩充状态之间全当成可连接的稠密图；内存中的状态数仍为 K^r 。代价增加来自保留了更长历史，而不是算法名称改变。

即使下一状态只依赖当前状态，设备保持某种工况的时长也未必符合 HMM 的隐含假设。若进入状态 i 后每步以概率 $a_{i,i} < 1$ 继续停留，则连续停留时长 D 服从

$$p(D = \ell | i) = (a_{i,i})^{\ell-1}(1 - a_{i,i}), \quad \mathbb{E}[D | i] = \frac{1}{1 - a_{i,i}}. \quad (28.11)$$

这是从 $\ell - 1$ 次自转移后接一次离开直接得到的**几何持续时间** (geometric duration)：已经待了多久，不会改变下一步离开的概率。本例正常状态的平均持续时间为 10 步；若真实设备通常至少运行 5 步才可能退出某工况，单一自转移概率就无法表达这种规律。

显式持续时间模型 (explicit-duration model) 为每个状态另给持续时间分布 $g_j(\ell)$ ；相应的**隐半 Markov 模型** (hidden semi-Markov model, HSMM) 在片段边界上转移，在片段内部保持同一状态。令边界转移概率为 $\tilde{a}_{i,j}$ ，通常约束 $\tilde{a}_{j,j} = 0$ 以免同一状态的相邻片段难以区分。若一个状态 j 片段长 ℓ 且结束于 t ，其条件观测似然为 $B_j(t, \ell) = \prod_{s=t-\ell+1}^t b_j(x_s)$ 。设序列从一个新片段开始，且 g_j 在 $\{1, \dots, D_{\max}\}$ 上归一化。记 $F_t(j)$ 为观测前缀与“一个 j 片段恰在 t 结束”的联合概率， $G_s(j)$ 为前 s 步观测与下一片段进入 j 的联合权重，则

$$\begin{aligned} G_0(j) &= \pi_j, \\ G_s(j) &= \sum_{i \neq j} F_s(i) \tilde{a}_{i,j}, \quad s \geq 1, \\ F_t(j) &= \sum_{\ell=1}^{\min(t, D_{\max})} g_j(\ell) B_j(t, \ell) G_{t-\ell}(j). \end{aligned} \quad (28.12)$$

这一递推同时枚举最后一个片段的长度和前一片段状态。若采样在固定 T 处停止而不保证片段结束，最后一段属于右删失数据。令 $\bar{g}_j(\ell) = p(D \geq \ell | j)$ ，则整体似然应按

$$p(x_{1:T}) = \sum_j \sum_{\ell=1}^{\min(T, D_{\max})} \bar{g}_j(\ell) B_j(T, \ell) G_{T-\ell}(j)$$

计算，而不是强行要求恰在 T 退出。若序列也从片段中途开始，初始剩余时长分布还要单独建模。预计算片段发射概率、缓存 $G_s(j)$ 后，式 (28.12) 的常规成本可由朴素的 $O(TD_{\max}K^2)$ 降为 $O(TK^2 + TD_{\max}K)$ ；这依赖这里的发射独立性与持续时间不依赖前驱状态的设定。无限支撑的持续时间若直接截断，还会增加截断误差。EM 仍使用后验期望计数，但统计对象变为片段、边界转移和持续时间。

另一种困难不是记忆长度，而是一个状态标签需要同时编码多个过程。例如，设备本体的健康状态与传感器的工作状态可能各有自己的持续规律。**因子 HMM** (factorial HMM) 把隐藏状态拆成多条链，令 $z_{t,m}$ 为第 m 条链的状态， $m = 1, \dots, M$ ，并设

$$p(\mathbf{z}_t | \mathbf{z}_{t-1}) = \prod_{m=1}^M p(z_{t,m} | z_{t-1,m}), \quad (28.13)$$

$$p(\mathbf{x}_t | \mathbf{z}_t) = p(\mathbf{x}_t | z_{t,1}, \dots, z_{t,M}).$$

不同链在先验转移中分开，观测却可以由它们共同产生。因此，观测一个共同结果之后，各链通常在后验中相关，不能分别运行独立 HMM 就得到精确解。每链 K 个状态时，联合接口有 K^M 种配置；利用转移的乘积结构可将一步预测按各维收缩，成本约为 $O(MK^{M+1})$ ，仍对链数呈指数增长。结构化变分可保留每条链内部的时间相关性而近似链间依赖，也可使用采样估计 E 步。因子 HMM 及这一后验耦合问题由 Ghahramani 和 Jordan 作了系统分析³。

³ Z. Ghahramani, M. I. Jordan, *Factorial Hidden Markov Models In Machine Learning*, 1997, vol. 29, pp. 245–273

28.3 连续与混合状态演化模型

只用正常、异常两个状态，可以判断工况，却不能细致追踪温度偏移或位置。若把这些连续量离散成许多格子，HMM 的状态数会迅速增大。另一条精确路线是保留连续状态，同时选择在预测和条件化后仍保持相同形式的分布族。**线性高斯状态空间模型** (linear Gaussian state space model, LGSSM) 假设状态与观测通过线性映射联系，随机扰动为高斯，因此整个有限序列具有联合高斯分布。

令潜状态 $\mathbf{z}_t \in \mathbb{R}^q$ 、观测 $\mathbf{x}_t \in \mathbb{R}^p$ 。齐次、无外部输入的基本模型为

$$\begin{aligned} \mathbf{z}_1 &\sim \mathcal{N}(\mathbf{m}_0, \mathbf{P}_0), \\ \mathbf{z}_t &= \mathbf{A}\mathbf{z}_{t-1} + \boldsymbol{\varepsilon}_t, \quad \boldsymbol{\varepsilon}_t \sim \mathcal{N}(\mathbf{0}, \mathbf{Q}), \\ \mathbf{x}_t &= \mathbf{C}\mathbf{z}_t + \boldsymbol{\eta}_t, \quad \boldsymbol{\eta}_t \sim \mathcal{N}(\mathbf{0}, \mathbf{R}). \end{aligned} \quad (28.14)$$

其中 $\mathbf{A} \in \mathbb{R}^{q \times q}$ 、 $\mathbf{C} \in \mathbb{R}^{p \times q}$ ， $\mathbf{Q}$ 和 $\mathbf{R}$ 分别是状态噪声、观测噪声协方差，所有噪声跨时刻相互独立，并与初始状态独立。这里 $\mathbf{A}$ 重新表示线性转移矩阵，不是上一节的概率转移表，不要求行和为 1。为使用下面的密度与逆

矩阵表达, 先取 $\mathbf{P}_0, \mathbf{Q}, \mathbf{R}$ 正定; 退化高斯需要单独处理其支撑子空间。已知控制量 $\mathbf{u}_t$ 可通过 $\mathbf{B}\mathbf{u}_t$ 加入状态方程, 时变矩阵也不破坏线性高斯递推, 只是不再满足齐次参数假设。

记 $\mathbf{m}_{t|s} = \mathbb{E}[\mathbf{z}_t | \mathbf{x}_{1:s}]$, $\mathbf{P}_{t|s} = \text{Cov}(\mathbf{z}_t | \mathbf{x}_{1:s})$ 。Kalman 滤波 (Kalman filtering) 用这两个量精确表示滤波后验; 它不仅平滑一条数值曲线, 还追踪曲线的不确定性。假设上一滤波后验为 $\mathcal{N}(\mathbf{m}_{t-1|t-1}, \mathbf{P}_{t-1|t-1})$, 线性变换与独立高斯噪声之和仍是高斯, 所以预测为

$$\begin{aligned}\mathbf{m}_{t|t-1} &= \mathbf{A}\mathbf{m}_{t-1|t-1}, \\ \mathbf{P}_{t|t-1} &= \mathbf{A}\mathbf{P}_{t-1|t-1}\mathbf{A}^\top + \mathbf{Q}.\end{aligned}\quad (28.15)$$

在 $t = 1$ 直接取 $\mathbf{m}_{1|0} = \mathbf{m}_0$ 、 $\mathbf{P}_{1|0} = \mathbf{P}_0$, 不额外执行一次状态转移。预测协方差中的第一项传播已有不确定性, 第二项加入这一步新产生的过程噪声。

观测怎样校正预测, 可以从联合高斯的条件分布直接推导。给定旧观测 $\mathbf{x}_{1:t-1}$, 把状态与新观测的联合均值、协方差分别记为 $\boldsymbol{\mu}_t, \boldsymbol{\Sigma}_t$, 则

$$\begin{aligned}\begin{pmatrix} \mathbf{z}_t \\ \mathbf{x}_t \end{pmatrix} \Big| \mathbf{x}_{1:t-1} &\sim \mathcal{N}(\boldsymbol{\mu}_t, \boldsymbol{\Sigma}_t), \\ \boldsymbol{\mu}_t &= \begin{pmatrix} \mathbf{m}_{t|t-1} \\ \mathbf{C}\mathbf{m}_{t|t-1} \end{pmatrix}, \\ \boldsymbol{\Sigma}_t &= \begin{pmatrix} \mathbf{P}_{t|t-1} & \mathbf{P}_{t|t-1}\mathbf{C}^\top \\ \mathbf{C}\mathbf{P}_{t|t-1} & \mathbf{S}_t \end{pmatrix},\end{aligned}\quad (28.16)$$

其中 $\mathbf{S}_t = \mathbf{C}\mathbf{P}_{t|t-1}\mathbf{C}^\top + \mathbf{R}$ 。对这个二次型配方, 相当于第 20 章的高斯条件化, 得到

$$\begin{aligned}\mathbf{e}_t &= \mathbf{x}_t - \mathbf{C}\mathbf{m}_{t|t-1}, \\ \mathbf{K}_t &= \mathbf{P}_{t|t-1}\mathbf{C}^\top \mathbf{S}_t^{-1}, \\ \mathbf{m}_{t|t} &= \mathbf{m}_{t|t-1} + \mathbf{K}_t \mathbf{e}_t, \\ \mathbf{P}_{t|t} &= \mathbf{P}_{t|t-1} - \mathbf{K}_t \mathbf{S}_t \mathbf{K}_t^\top.\end{aligned}\quad (28.17)$$

$\mathbf{e}_t$ 称为**新息** (innovation), 即实际观测与预测观测之差; $\mathbf{K}_t$ 称为**Kalman 增益** (Kalman gain), 决定这段差异应有多少被解释为状态修正。它把状态与观测的预测交叉协方差乘以新息协方差的逆, 因而不是人为固定的平滑系数。

标量、 $\mathbf{C} = 1$ 时, 增益为 $K_t = P_{t|t-1}/(P_{t|t-1} + R)$ 。预测越不确定, 观测对后验均值影响越大; 观测噪声越大, 更新越依赖预测。在当前线性高斯假设下, 条件协方差不依赖实际观测数值, 且被减去的 $\mathbf{K}_t \mathbf{S}_t \mathbf{K}_t^\top$ 半正定, 所以一次观测更新不会增加协方差。不过, 下一步预测还会加入 $\mathbf{Q}$, 不能

据此声称滤波方差随时间单调下降。

线性高斯性在每一步都保持，初始分布又是高斯，因此式 (28.15) 与式 (28.17) 的归纳应用证明了滤波的精确性。若只有线性与二阶矩条件而没有高斯性，同样形式可在相应条件下给出最佳线性均方估计，但不再一般等于完整后验或所有估计器中的条件均值。这一区别决定了能否把一个均值和协方差解释为全部不确定性。

计算时不应显式形成 $\mathbf{S}_t^{-1}$ ，而应通过 Cholesky 分解等方法解线性方程。为了减轻浮点消减导致的非对称或负方差，可以使用等价的 Joseph 协方差形式

$$\begin{aligned} \mathbf{P}_{t|t} &= (\mathbf{I} - \mathbf{K}_t \mathbf{C}) \mathbf{P}_{t|t-1} (\mathbf{I} - \mathbf{K}_t \mathbf{C})^\top \\ &\quad + \mathbf{K}_t \mathbf{R} \mathbf{K}_t^\top, \end{aligned} \quad (28.18)$$

或直接传播协方差的平方根因子。若某个时刻完全没有观测且缺失机制可忽略，就只做预测；若只有部分坐标缺失，就用实际观测对应的 $\mathbf{C}$ 行和 $\mathbf{R}$ 子矩阵更新。缺失是否可忽略仍需第 24 章的条件，不能默认传感器恰在极端状态时失灵也不影响推断。

Kalman 滤波还提供每一步的预测观测密度 $\mathcal{N}(\mathbf{x}_t; \mathbf{C} \mathbf{m}_{t|t-1}, \mathbf{S}_t)$ 。因此观测对数似然为

$$\log p(\mathbf{x}_{1:T}) = -\frac{1}{2} \sum_{t=1}^T \left[p \log(2\pi) + \log |\mathbf{S}_t| + \mathbf{e}_t^\top \mathbf{S}_t^{-1} \mathbf{e}_t \right]. \quad (28.19)$$

这使参数选择和预测误差处在同一个概率口径中。完整观测、密集矩阵的常规每步代价为 $O(q^3 + p^3 + q^2 p + qp^2)$ ；在线状态存储为 $O(q^2)$ ，若还计入观测工作空间，则需保存大小约为 $p^2 + pq$ 的矩阵。固定维度时，序列总成本对 T 线性。

回看早期状态时，新观测也需要沿时间反向传递。**Rauch-Tung-Striebel 平滑** (Rauch-Tung-Striebel smoothing, RTS smoothing) 在前向滤波后，利用相邻状态之间的条件高斯关系反向更新。给定 $\mathbf{x}_{1:t}$ ， $\mathbf{z}_t$ 与 $\mathbf{z}_{t+1}$ 的交叉协方差为 $\mathbf{P}_{t|t} \mathbf{A}^\top$ ，所以定义

$$\mathbf{J}_t = \mathbf{P}_{t|t} \mathbf{A}^\top \mathbf{P}_{t+1|t}^{-1}.$$

条件分布 $p(\mathbf{z}_t | \mathbf{z}_{t+1}, \mathbf{x}_{1:t})$ 的均值为

$$\mathbf{m}_{t|t} + \mathbf{J}_t (\mathbf{z}_{t+1} - \mathbf{m}_{t+1|t}),$$

协方差为 $\mathbf{P}_{t|t} - \mathbf{J}_t \mathbf{P}_{t+1|t} \mathbf{J}_t^\top$ 。给定下一状态后，更晚观测不再为当前状态提供额外信息；把上面的条件分布按 $p(\mathbf{z}_{t+1} | \mathbf{x}_{1:T})$ 积分，用全期望与全协方

差公式得到

$$\begin{aligned} \mathbf{m}_{t|T} &= \mathbf{m}_{t|t} + \mathbf{J}_t(\mathbf{m}_{t+1|T} - \mathbf{m}_{t+1|t}), \\ \mathbf{P}_{t|T} &= \mathbf{P}_{t|t} + \mathbf{J}_t(\mathbf{P}_{t+1|T} - \mathbf{P}_{t+1|t})\mathbf{J}_t^\top. \end{aligned} \quad (28.20)$$

从 $t = T$ 处的滤波结果开始, 依次取 $t = T - 1, \dots, 1$ 。平滑不是把观测倒序再运行一次原来的滤波器, 因为逆向条件转移依赖前向滤波分布, 并不一般等于原来的状态转移。保存前向均值、协方差与预测量后, 常规平滑需 $O(Tq^2)$ 存储和 $O(Tq^3)$ 的额外密集矩阵计算。

参数学习还需要相邻状态的联合矩。由同一个条件均值表达, 残差与 $\mathbf{z}_{t+1}$ 条件不相关, 得到

$$\begin{aligned} \mathbf{P}_{t,t-1|T} &:= \text{Cov}(\mathbf{z}_t, \mathbf{z}_{t-1} \mid \mathbf{x}_{1:T}) \\ &= \mathbf{P}_{t|T}\mathbf{J}_{t-1}^\top, \quad t = 2, \dots, T. \end{aligned} \quad (28.21)$$

这个方向不能颠倒: $\mathbf{J}_{t-1}\mathbf{P}_{t|T}$ 对应的是 $\text{Cov}(\mathbf{z}_{t-1}, \mathbf{z}_t \mid \mathbf{x}_{1:T})$ 。滞后一阶协方差一般不为零; 仅把相邻平滑均值相乘, 会遗漏学习动态关系所需的不确定性。

示例 28.3 温度偏移的滤波、平滑与二阶矩 用另一个人工模型追踪设备的温度偏移, 温度单位记为摄氏度。设 $Z_1 \sim \mathcal{N}(0, 1)$ 、 $Z_2 = Z_1 + \varepsilon_2$ 、 $X_t = Z_t + \eta_t$, 过程噪声和观测噪声均独立服从 $\mathcal{N}(0, 1)$, 方差单位为摄氏度平方。给定 $x_1 = 1, x_2 = 2$, 第一次滤波得到 $K_1 = 1/2$ 、 $m_{1|1} = 0.5$ 、 $P_{1|1} = 0.5$ 。第二次预测为 $m_{2|1} = 0.5$ 、 $P_{2|1} = 1.5$, 故 $K_2 = 1.5/2.5 = 0.6$, 更新得到

$$m_{2|2} = 0.5 + 0.6(2 - 0.5) = 1.4, \quad P_{2|2} = 0.6.$$

平滑增益 $J_1 = 0.5/1.5 = 1/3$, 于是

$$\begin{aligned} m_{1|2} &= 0.5 + (1/3)(1.4 - 0.5) = 0.8, \\ P_{1|2} &= 0.5 + (1/3)^2(0.6 - 1.5) = 0.4, \\ P_{2,1|2} &= 0.6/3 = 0.2. \end{aligned}$$

第二次观测把第一次的状态均值从 0.5 调到 0.8, 而不是直接改成第二次的读数 2。两个状态的联合平滑协方差为 $\begin{pmatrix} 0.4 & 0.2 \\ 0.2 & 0.6 \end{pmatrix}$, 保留了相邻状态共享的不确定性。

同一递推可以直接用于二维位置。图 28.2 采用随机游走 $\mathbf{z}_t = \mathbf{z}_{t-1} + \varepsilon_t$ 与直接观测 $\mathbf{x}_t = \mathbf{z}_t + \eta_t$, 固定 $\mathbf{Q} = \text{diag}(0.8, 0.5)$ 、 $\mathbf{R} = \text{diag}(0.45, 0.3)$ 及 $\mathbf{P}_0 = 0.4\mathbf{I}$ 。一步预测只延续上一滤波状态, 因而落后于持续移动的目标; 当前观测把滤波点拉向测量, 后来的观测又通过 RTS 反向递推修正早期位置。这里的真值仅用于展示估计误差, 不被滤波或平滑算法读取。




图 28.2 二维 Kalman 滤波与 RTS 平滑的可复算轨迹。黑色虚线是人工真值，灰叉是固定观测，蓝色空心点为观测前的一步预测，红色方点为在线滤波均值，黄色三角为使用全部九次观测的平滑均值。红色半透明椭圆分别给出 $t = 2, 5, 8$ 处滤波后验的逐坐标 1 倍标准差区域；末时刻没有未来观测，滤波与平滑重合。模型参数和全部坐标固定写在图源中，不表示任意运动都适合随机游走模型。

图 28.3 画出例 28.3 第二时刻的三个密度。观测似然的位置偏向 2，预测密度的位置偏向 0.5，二者乘积归一化后的均值为 1.4；较窄的后验反映独立信息的结合，而不是随意缩小误差条。

若线性映射与噪声方差未知，只求状态均值还没有完成建模。线性高斯模型的 EM 与 Baum-Welch 具有相同结构：E 步计算完全数据对数似然所需的后验统计量，M 步拟合局部条件分布。不过，离散模型需要期望计数，连续模型需要期望的一阶与二阶矩。记当前参数下

$$\begin{aligned}
 \bar{\mathbf{z}}_t &= \mathbf{m}_{t|T}, \\
 \mathbf{M}_t &:= \mathbb{E}[\mathbf{z}_t \mathbf{z}_t^\top | \mathbf{x}_{1:T}] = \mathbf{P}_{t|T} + \bar{\mathbf{z}}_t \bar{\mathbf{z}}_t^\top, \\
 \mathbf{M}_{t,t-1} &:= \mathbb{E}[\mathbf{z}_t \mathbf{z}_{t-1}^\top | \mathbf{x}_{1:T}] \\
 &= \mathbf{P}_{t,t-1|T} + \bar{\mathbf{z}}_t \bar{\mathbf{z}}_{t-1}^\top.
 \end{aligned} \tag{28.22}$$

全部期望都来自同一组旧参数，不能在一次 M 步内部改变这些统计量。线性系统 EM 的完全数据似然与这些充分统计量可参见 Ghahramani 和 Hinton 的推导⁴。

为说明更新从何而来，令转移残差为 $\mathbf{r}_t(\mathbf{A}) = \mathbf{z}_t - \mathbf{A}\mathbf{z}_{t-1}$ ，展开它的期望外积：

$$\begin{aligned}
 \mathbf{E}_t(\mathbf{A}) &:= \mathbb{E}[\mathbf{r}_t(\mathbf{A}) \mathbf{r}_t(\mathbf{A})^\top | \mathbf{x}_{1:T}] \\
 &= \mathbf{M}_t - \mathbf{A} \mathbf{M}_{t,t-1}^\top - \mathbf{M}_{t,t-1} \mathbf{A}^\top \\
 &\quad + \mathbf{A} \mathbf{M}_{t-1} \mathbf{A}^\top.
 \end{aligned} \tag{28.23}$$

⁴ Z. Ghahramani, G. E. Hinton, *Parameter Estimation for Linear Dynamical Systems*, Technical Report CRG-TR-96-2, Department of Computer Science, University of Toronto, Feb. 22, 1996




图 28.3 标量 Kalman 更新的可复算密度。蓝色实线为预测 $\mathcal{N}(0.5, 1.5)$ ，灰色虚线为对状态归一化后的似然 $\mathcal{N}(2, 1)$ ，红色粗线为后验 $\mathcal{N}(1.4, 0.6)$ ，并由曲线旁的引线直接标出。横轴是温度偏移，纵轴是密度；本例观测矩阵为 1，似然才可直接画成同一坐标下的归一化密度。

观测残差 $D_t(\mathbf{C})$ 同理为

$$D_t(\mathbf{C}) = \mathbf{x}_t \mathbf{x}_t^\top - \mathbf{C} \bar{\mathbf{z}}_t \mathbf{x}_t^\top - \mathbf{x}_t \bar{\mathbf{z}}_t^\top \mathbf{C}^\top + \mathbf{C} \mathbf{M}_t \mathbf{C}^\top.$$

除去初始分布项和与参数无关的常数，EM 的辅助目标为

$$\begin{aligned} \mathcal{Q} = & -\frac{T-1}{2} \log |\mathbf{Q}| - \frac{1}{2} \sum_{t=2}^T \text{tr}\{\mathbf{Q}^{-1} \mathbf{E}_t(\mathbf{A})\} \\ & - \frac{T}{2} \log |\mathbf{R}| - \frac{1}{2} \sum_{t=1}^T \text{tr}\{\mathbf{R}^{-1} D_t(\mathbf{C})\} \\ & + \text{初始项} + \text{常数}. \end{aligned} \quad (28.24)$$

这表明 $\mathbf{M}$ 步是一组使用后验二阶矩的线性回归与协方差估计，不是简单地把平滑均值当成无误差的训练标签。

在 $T \geq 2$ 、完整观测且相关二阶矩和可逆时，对 $\mathbf{A}$ 求导得到正规方程

$$\mathbf{A}^{(k+1)} \sum_{t=2}^T \mathbf{M}_{t-1} = \sum_{t=2}^T \mathbf{M}_{t,t-1}.$$

观测回归有同样形式, 因此

$$\begin{aligned}
 \mathbf{A}^{(k+1)} &= \left(\sum_{t=2}^T \mathbf{M}_{t,t-1} \right) \left(\sum_{t=2}^T \mathbf{M}_{t-1} \right)^{-1}, \\
 \mathbf{C}^{(k+1)} &= \left(\sum_{t=1}^T \mathbf{x}_t \bar{\mathbf{z}}_t^\top \right) \left(\sum_{t=1}^T \mathbf{M}_t \right)^{-1}, \\
 \mathbf{Q}^{(k+1)} &= \frac{1}{T-1} \sum_{t=2}^T \mathbf{E}_t(\mathbf{A}^{(k+1)}), \\
 \mathbf{R}^{(k+1)} &= \frac{1}{T} \sum_{t=1}^T \mathbf{D}_t(\mathbf{C}^{(k+1)}).
 \end{aligned} \tag{28.25}$$

协方差更新可由对 $\mathbf{Q}^{-1}$ 或 $\mathbf{R}^{-1}$ 求导得到: 例如转移项的一阶条件是 $(T-1)\mathbf{Q} = \sum_t \mathbf{E}_t$ 。初始参数的无约束更新为 $\mathbf{m}_0^{(k+1)} = \bar{\mathbf{z}}_1$ 、 $\mathbf{P}_0^{(k+1)} = \mathbf{P}_{1|T}$ 。有 n 条独立序列时, $\mathbf{m}_0^{(k+1)}$ 改为各序列初始平滑均值的平均, $\mathbf{P}_0^{(k+1)}$ 则平均“初始平滑协方差加初始均值相对总体均值的外积”; 转移项的分母为 $\sum_{\ell=1}^n (T_\ell - 1)$, 观测项的分母为 $\sum_{\ell=1}^n T_\ell$ 。这避免把不同序列之间的初始差异丢掉。

例 28.3 给出 $M_1 = 0.4 + 0.8^2 = 1.04$ 、 $M_2 = 0.6 + 1.4^2 = 2.56$ 和 $M_{2,1} = 0.2 + 1.4 \times 0.8 = 1.32$ 。从旧参数 $\mathbf{A} = \mathbf{C} = \mathbf{Q} = \mathbf{R} = \mathbf{I}$ 进行一次无约束 $\mathbf{M}$ 步, 可得

$$\begin{aligned}
 \mathbf{A}^{(k+1)} &= 1.32/1.04 = 33/26, \\
 \mathbf{C}^{(k+1)} &= (1 \times 0.8 + 2 \times 1.4)/(1.04 + 2.56) = 1, \\
 \mathbf{Q}^{(k+1)} &= 2.56 - 1.32^2/1.04 = 23/26, \\
 \mathbf{R}^{(k+1)} &= (1^2 + 2^2 - 3.6)/2 = 0.7.
 \end{aligned}$$

初始均值与方差更新为 0.8 和 0.4。这里 $\mathbf{A}^{(k+1)} > \mathbf{I}$ 不违背 EM, 因为这次极大化没有施加稳定性约束, 两个观测也不足以可靠识别全部系统参数。若建模目标要求稳定动力学, 就应明确限制 $\mathbf{A}$ 的谱半径, 使用对应的约束 $\mathbf{M}$ 步, 而不是先做无约束更新再假定它稳定。

每轮 EM 包含一次滤波和平滑, 再累计矩, 固定维度时仍对总序列长度线性。可使用似然增量和迭代上限停止, 保留多组初值并检查观测预测。若二阶矩和奇异, 线性映射可能没有唯一估计; 若协方差估计落在退化边界, 则普通正定密度公式失效。协方差下界、先验、已知噪声结构或固定部分参数都可能必要, 但它们改变了无约束最大似然问题, 必须相应调整目标与更新。

连续潜状态还有比标签交换更广的坐标不确定性。对任意可逆矩阵 $\mathbf{H}$, 令 $\tilde{\mathbf{z}}_t = \mathbf{H}\mathbf{z}_t$, 同时取 $\tilde{\mathbf{A}} = \mathbf{H}\mathbf{A}\mathbf{H}^{-1}$ 、 $\tilde{\mathbf{C}} = \mathbf{C}\mathbf{H}^{-1}$ 、 $\tilde{\mathbf{Q}} = \mathbf{H}\mathbf{Q}\mathbf{H}^\top$ 并变换初始分布, 观测分布不变。因此, 学得的某个状态坐标不能自动解释为“温度”

或“磨损程度”；这些语义需要测量关系或其他约束。若有非零方向始终不被 $\mathbf{C}, \mathbf{CA}, \dots$ 看到，观测还难以约束该方向。滤波公式能执行、潜状态可识别、长期误差有界，是三个不同问题。

单一线性动态也可能过于严格：设备可能在升温、恒温、冷却等模式之间切换，每个模式内部近似线性，但整体不是同一个线性系统。**切换线性动态系统**（switching linear dynamical system, SLDS）加入离散模式 $S_t \in \{1, \dots, L\}$ ，用模式选择连续状态的转移与观测机制。这里 S_t 是新引入的模式变量，不是四节点例中表示传感器失灵的 S 。一个常见形式为

$$\begin{aligned} p(s_t | s_{t-1}) &= \omega_{s_{t-1}, s_t}, \\ \mathbf{z}_t | \mathbf{z}_{t-1}, s_t &\sim \mathcal{N}(\mathbf{A}_{s_t} \mathbf{z}_{t-1}, \mathbf{Q}_{s_t}), \\ \mathbf{x}_t | \mathbf{z}_t, s_t &\sim \mathcal{N}(\mathbf{C}_{s_t} \mathbf{z}_t, \mathbf{R}_{s_t}), \end{aligned} \quad (28.26)$$

并另给 $p(s_1)$ 及条件高斯初始分布 $p(\mathbf{z}_1 | s_1) = \mathcal{N}(\mathbf{z}_1; \mathbf{m}_{0, s_1}, \mathbf{P}_{0, s_1})$ ，沿上述局部条件分布生成序列。图 28.4 展示离散模式如何影响连续状态；模式本身也是潜在的，所以不能仅凭当前读数先硬选一个模式再宣称得到精确滤波。




图 28.4 切换线性动态系统的三层展开。方形节点为离散模式，空心圆为连续状态，填充圆为观测。给定完整模式路径后，连续部分可用 Kalman 递推；只给定当前模式不足以合并具有不同历史的所有高斯分量。

给定一条模式历史 $s_{1:t}$ ，连续状态条件后验仍为高斯；但不同模式历史通常产生不同均值和协方差。因此，精确滤波一般是最多包含 L^t 个分量的高斯混合，而不是每种当前模式只维护一个高斯就足够。合并分量、剪枝或限制每种模式的混合数能够控制成本，却都引入近似。参数学习可以把模式转移的期望计数与各模式下的连续二阶矩组合成 EM，但其 E 步正是上述混合推断问题；切换模式越复杂，学习越依赖近似后验的质量。

如果设备动力学本来就是非线性的，或者噪声包含离群点、偏斜和离散

跳变,则需要更一般的状态空间模型。加性噪声下可写为

$$\mathbf{z}_t = f_t(\mathbf{z}_{t-1}) + \varepsilon_t, \quad \mathbf{x}_t = h_t(\mathbf{z}_t) + \eta_t. \quad (28.27)$$

也可以直接指定非高斯转移密度与观测密度,而不要求存在这种加性表示。共同的 Bayes 递推式 (28.3) 仍成立;变化的是后验不再通常落在单个高斯族中。选择近似方法时,应分清近似的是动力学函数、积分中的矩,还是整个状态路径后验。

扩展 Kalman 滤波 (extended Kalman filter, EKF) 在当前估计附近对非线性函数作一阶线性化,再使用高斯递推。对加性高斯噪声,令 $\mathbf{F}_t$ 为 f_t 在 $\mathbf{m}_{t-1|t-1}$ 处的 Jacobian,令 $\mathbf{H}_t$ 为 h_t 在预测均值处的 Jacobian,则

$$\begin{aligned} \mathbf{m}_{t|t-1} &\approx f_t(\mathbf{m}_{t-1|t-1}), \\ \mathbf{P}_{t|t-1} &\approx \mathbf{F}_t \mathbf{P}_{t-1|t-1} \mathbf{F}_t^\top + \mathbf{Q}_t, \\ \mathbf{S}_t &\approx \mathbf{H}_t \mathbf{P}_{t|t-1} \mathbf{H}_t^\top + \mathbf{R}_t. \end{aligned}$$

更新中的预测观测改用 $h_t(\mathbf{m}_{t|t-1})$,增益则使用 $\mathbf{P}_{t|t-1} \mathbf{H}_t^\top \mathbf{S}_t^{-1}$ 。EKF 近似了局部函数以及由此导出的矩,适合函数可微且后验集中于线性化有效区域的情况。初值偏离、强曲率或多峰后验会使这一局部近似失效。

无迹变换 (unscented transform, UT) 不求导数,而是选择少量确定性代表点,让它们通过非线性函数,再从变换后的点估计均值与协方差。给定 q 维高斯近似 $\mathcal{N}(\mathbf{m}, \mathbf{P})$,取 $\mathbf{L}\mathbf{L}^\top = \mathbf{P}$ 、 $\kappa > 0$,一种简单的 $2q+1$ 点规则是

$$\begin{aligned} \chi_0 &= \mathbf{m}, & w_0 &= \frac{\kappa}{q + \kappa}, \\ \chi_i &= \mathbf{m} + \sqrt{q + \kappa} \mathbf{L}_{:,i}, & w_i &= \frac{1}{2(q + \kappa)}, \\ \chi_{q+i} &= \mathbf{m} - \sqrt{q + \kappa} \mathbf{L}_{:,i}, & w_{q+i} &= \frac{1}{2(q + \kappa)}, \end{aligned}$$

其中 $i = 1, \dots, q$ 。这些点的加权均值和协方差恰好为 $\mathbf{m}, \mathbf{P}$ 。经过函数 f 后,用 $\hat{\boldsymbol{\mu}} = \sum_i w_i f(\chi_i)$ 及 $\sum_i w_i (f(\chi_i) - \hat{\boldsymbol{\mu}})(f(\chi_i) - \hat{\boldsymbol{\mu}})^\top$ 近似变换后的矩。将这一积分规则用于预测状态、预测观测及其交叉协方差,再作高斯条件化,就得到**无迹 Kalman 滤波** (unscented Kalman filter, UKF)。

例如 $Z \sim \mathcal{N}(0, 1)$ 、 $f(Z) = Z^2$ 时, EKF 在 0 处的函数值和导数均为 0, 预测均值与方差都会给成 0, 而精确值为 1 和 2。取 $q = 1, \kappa = 2$, 上述点为 $0, \sqrt{3}, -\sqrt{3}$ 、权重为 $2/3, 1/6, 1/6$, 变换后得到 $0, 3, 3$, 恰好恢复均值 1 和方差 2。这个结果只说明该积分规则在这个例子中捕捉到了曲率,不能据此推断任意非线性函数都精确。UT 通常只近似有限阶矩, UKF 还把后验压缩成单个高斯,因而同样无法忠实保留相互分离的多个峰。EKF、UT 及其平滑扩展的系统条件与算法可参见 Särkkä 和 Svensson 的教材⁵。

⁵ S. Särkkä, L. Svensson, *Bayesian Filtering and Smoothing*, Cambridge University Press, 2023, 2nd ed.

当任务是整段状态重建或参数学习，**变分状态估计** (variational state estimation) 可以直接选择一个便于计算的路径分布 $q_\phi(\mathbf{z}_{1:T})$ ，最大化第 22 章的证据下界。在线性或局部二次近似下，保留相邻时刻相关性的结构化高斯族往往比逐时刻独立近似更合适；切换系统也可以令近似分布包含一个离散模式链与一个连续状态链。它近似的是联合后验的依赖或分布形状，而不只是把某个 Jacobian 换成数值积分。优化下界方便与参数学习结合，但下界提高不等于精确似然提高，过窄的近似族还可能漏掉后验分支。

若后验明显多峰，用单个均值与协方差描述会掩盖不同解释。**粒子滤波** (particle filtering) 以一组带权状态样本近似滤波分布，使不同粒子保留不同可能状态。设粒子数为 n ，第 i 个粒子记作 $\mathbf{z}_{t,i}$ ，从 $q_t(\mathbf{z}_t | \mathbf{z}_{t-1,i}, \mathbf{x}_t)$ 提议后，在未重采样的一步中更新

$$w_{t,i} \propto w_{t-1,i} \frac{p(\mathbf{x}_t | \mathbf{z}_{t,i})p(\mathbf{z}_{t,i} | \mathbf{z}_{t-1,i})}{q_t(\mathbf{z}_{t,i} | \mathbf{z}_{t-1,i}, \mathbf{x}_t)}.$$

若先按旧权重重采样了祖先，则新权重不再重复乘旧祖先权重。式 (23.19) 已推导序贯重要性权重，算法 23.2 给出了包含重采样的自举滤波；这里的作用是指出它们适合替代难以闭合的连续积分。转移先验提议可以简化权重，但观测很集中时，大部分粒子可能落在低似然区域。每步约为 n 次转移与似然求值加重采样成本，粒子数必须随问题难度增加，并非固定 n 就能保证高维或长时间下准确。

对式 (28.26) 还可以只抽样模式路径，每个粒子内部用精确 Kalman 滤波处理连续状态，这就是第 23 章的 Rao-Blackwell 化粒子方法在本章模型上的实例。它利用的是“给定模式历史后条件线性高斯”，而不是假设整体后验高斯。在线滤波准确也不自动保证长路径平滑准确，因为重采样会使许多粒子共享早期祖先；离线平滑和 EM 应使用专门的粒子平滑或其他路径后验方法。数值方法的选择最终取决于需要保留哪种不确定性，以及允许支付多少计算成本。

28.4 模型比较

这些模型共享时间上的有向分解，却不共享同一种状态表示。比较时需要同时确定：状态是否可见，隐藏状态是有限集合还是连续空间，转移依赖哪些历史，以及当前任务使用多长范围的证据。表 28.2 将这些条件放在同一口径下。DBN 不列为一个与 HMM 竞争的模型行，因为它是各行都可以使用的表示框架。

有限状态动态规划和 Kalman 递推为何都能对序列长度做到线性？共同原因是每一步把整个过去压缩成大小不随时间增长的精确消息。前者保存 K 个状态概率，后者保存一个均值向量和一个协方差矩阵。有限接口本身还不够：因子 HMM 的接口虽不随时间增加，却可能有 K^M 种联合配置；

模型	状态可见性与空间	转移假设	常见查询	推断与学习
有限 Markov 链	可见、离散	当前状态决定下一状态	多步预测、长期分布	矩阵递推；可见转移计数
HMM	隐藏、离散	一阶链，几何停留时间	滤波、平滑、整条路径	前向-后向、Viterbi；Baum-Welch
高阶 HMM 与 HSMM	隐藏、离散或分段状态	更长历史或显式持续时间	路径与片段边界	扩充状态或片段动态规划；期望计数
因子 HMM	多条隐藏离散链	先验转移分开，观测耦合	联合滤波与平滑	联合表可精确但指数增长；变分或采样
线性高斯模型	隐藏、连续	线性转移与独立高斯噪声	状态分布、预测密度	Kalman 滤波、RTS 平滑；二阶矩 EM
切换线性系统	隐藏、离散与连续混合	模式选择线性动态	模式与连续状态联合查询	高斯混合枚举一般指数增长；混合约简或条件粒子方法
一般状态空间模型	隐藏、连续或混合	非线性、非高斯等	滤波、平滑及预测风险	局部线性化、矩近似、变分或粒子方法

表 28.2 按状态与转移假设比较动态有向模型。所有行都需另给初始分布；线性高斯模型的解析结论要求初始状态也为高斯。表中的近似方法不存在与模型名称一一对应的唯一选择。

切换系统的连续混合分量又会随模式历史增加。复杂度必须同时观察时间长度、接口维度和消息的表示复杂度。

查询目标也会改变所需算法。在线控制只能使用当前及过去观测，不能把平滑结果当作实时滤波的性能；事后检修可以等待未来观测，通常更适合平滑。若代价按每个时刻是否判错计算，离散平滑边缘的逐时刻最优决策有直接意义；若必须选择一条满足转移限制的整体解释，就需要路径优化。连续联合高斯后验的均值同时也是其联合密度众数，而混合后验的平均值可能落在各分量之间的低密度区域，不能把这种特殊一致性推广到切换模型。

模型偏差与推断误差应分开诊断。HMM 精确前向-后向算出的后验，仍可能受到错误持续时间或过少状态的影响；EKF 的误差则既可能来自动力学不合适，也可能来自局部线性化。对同一任务比较方法时，应固定训练与测试时间边界，报告一步或多步预测对数密度、状态误差与计算成本，并检查不确定性是否与观测相容。任意随机打乱时间点，或把平滑时用到的未来观测泄漏给预测器，都会改变原本要评估的问题。

参数共享减少了自由参数，在共享假设合理时有助于降低估计所需的数据量，却也限制了适应变化的能力。若运行环境发生变化，继续用旧的齐次参数可能系统性失配；加入已知输入、时变参数或模式切换可以表达这种变化，但增加状态或参数后又需要更多信息来识别。建模选择应从哪些依赖确有必要开始，再检查相应后验能否以可承受的成本表示，而不是先选一种熟悉的滤波器，再假定系统满足它的全部条件。

28.5 本章小结

连续到来的观测之所以可以递推处理，是因为动态有向分解把过去对未来的影响集中到一个时间接口上。DBN 描述这一依赖模板；一阶 Markov 性说明给定状态后哪些历史可以不再显式保留，时间齐次与参数共享说明局部机制是否复用，平稳性则描述整个过程的分布是否随时间平移而改变。这些条件各自约束不同对象，不能相互替代。

对有限隐藏状态，前向-后向算法精确累加路径，Viterbi 算法保留并回溯最优路径，Baum-Welch 再把平滑后验变成期望计数。对连续线性高斯状态，预测与条件化保持高斯形式，Kalman 滤波和 RTS 平滑因而只需传播均值、协方差与学习所需的相邻二阶矩。离散与连续算法的联系落在同一件事上：用可复用的局部消息完成全局推断，再用后验统计量学习局部条件分布。

回到设备监测的问题，当前报警判断、事后故障追溯和整段状态解释需要不同的查询；同一数据上的答案可以不同，并不矛盾。状态空间变大、持续时间变复杂或离散模式与连续动态混合后，精确消息可能不再廉价，局部高斯、变分和粒子方法便在不同位置作出近似。明确哪些不确定性被保留、哪些依赖被省略，并把这些选择与实际查询和可用数据联系起来，才使动态模型给出的概率具有可解释的边界。

概率生成模型

给一张图像赋予概率，与从随机数生成一张图像，是同一个模型的两种用法，却不一定具有相同的计算难度。一个网络可以迅速生成样本，但无法回答某个给定样本的密度；另一个模型可以精确计算完整观测的似然，却需要许多顺序步骤才能生成新样本。前文的图分解、边缘化和近似推断，正好提供了区分这些情况的工具：需要计算的概率是什么，哪些变量尚未观测，困难又落在哪个求和、积分或变换上？

本章围绕三个相互关联的问题展开：复杂的观测分布怎样保持归一化，训练时实际优化的量与似然是什么关系，生成一个新样本需要付出什么代价。潜变量边缘化、可逆变量变换和人工随机过程分别给出一种答案。三者都可以使用神经网络，但网络在其中承担的概率角色不同。理解这些角色，比把生成模型视为网络名称的列表更能帮助我们判断它们的能力与边界。

29.1 概率生成模型的共同问题

设训练样本 $\mathbf{x}_1, \dots, \mathbf{x}_n$ 独立同分布地来自未知分布 p_{data} ，希望用参数向量 θ 确定的 p_θ 近似它。除特别说明外，本章讨论 $\mathbf{x} \in \mathbb{R}^d$ 上的连续密度，概率都是对区域积分得到的；密度在一个点上可以大于 1。二值或离散观测使用概率质量函数，不能把连续密度值直接当成某个像素取值的概率。

概率生成模型 (probabilistic generative model) 为可能出现的观测规定一个分布，并据此生成新观测。对显式密度模型，归一化要求 $\int p_\theta(\mathbf{x}) d\mathbf{x} = 1$ 。最大似然学习最小化

$$J(\theta) = -\frac{1}{n} \sum_{i=1}^n \log p_\theta(\mathbf{x}_i). \quad (29.1)$$

这个表达式很短，但它没有说明每个对数密度如何计算。若模型含有潜变量，边缘化可能使似然难以求值；若只提供一个从噪声到数据的程序，则分布虽然存在，也未必有可计算的密度。训练、密度评价、采样和潜变量推断因此需要分别说明。

第 26.1.2 节的自回归模型提供了一个基线：用已归一化的一维条件分布按链式法则构成联合分布，完整观测的似然可精确评价，通常的祖先采样则要按给定顺序生成各个分量。本章不重复其网络参数化。下面比较的三种机制把困难放在别处：VAE 对一个联合分布中的潜变量积分；规范化流通过双射追踪体积变化；扩散模型把生成拆成许多局部随机转移。

这不是对生成模型的穷尽分类，也不是三种新的条件独立性图语义。VAE 直接使用有向潜变量图；离散扩散可以写成沿人工噪声索引展开的有向 Markov 链；规范化流的密度则来自确定性双射和变量变换公式。一个双射的计算图不自动具有有向图模型的条件独立性含义。后文还会用概率电路作补充比较：除了放宽函数形式，也可以限制计算结构，换取精确的边缘化和条件查询。

为使三种机制可直接核对，本章反复使用人为构造的一维目标 $X \sim \mathcal{N}(0, 5)$ 。它可以由两个独立高斯变量相加得到，也可以由标准高斯缩放得到，还可以作为前向扩散的起点。这个例子没有复杂数据的表达难题，却能把分布、密度和随机路径之间的区别算清楚。

29.2 变分自编码器

29.2.1 有向潜变量模型

如果观测中的相关变化由少量未观测因素共同引起，可以先生成这些因素，再生成观测。**变分自编码器** (variational autoencoder, VAE) 将这种有向潜变量模型与可学习的近似后验结合起来：生成网络规定潜变量怎样产生观测，推断网络则根据观测估计哪些潜变量较为可能。它不是仅仅把输入压缩后还原的确定性自编码器¹。

令 $\mathbf{z} \in \mathbb{R}^k$ ，通常取先验 $p(\mathbf{z}) = \mathcal{N}(\mathbf{0}, \mathbf{I}_k)$ ，再用神经网络输出条件分布 $p_\theta(\mathbf{x} | \mathbf{z})$ 的参数。生成联合分布与观测边缘分布为

$$\begin{aligned} p_\theta(\mathbf{x}, \mathbf{z}) &= p(\mathbf{z})p_\theta(\mathbf{x} | \mathbf{z}), \\ p_\theta(\mathbf{x}) &= \int p(\mathbf{z})p_\theta(\mathbf{x} | \mathbf{z}) d\mathbf{z}. \end{aligned} \quad (29.2)$$

只要先验和每个条件分布都归一化，非负积分交换便说明观测分布也归一化。难点不是证明积分等于 1，而是对某个 $\mathbf{x}$ 计算这个积分的数值。

以连续观测为例，**解码器** (decoder) 不是直接输出唯一的 $\mathbf{x}$ ，而是输出观测分布的参数。一个常用设定是

$$p_\theta(\mathbf{x} | \mathbf{z}) = \mathcal{N}(\mathbf{x}; \mathbf{g}_\theta(\mathbf{z}), \tau^2 \mathbf{I}_d), \quad \tau > 0. \quad (29.3)$$

其中 $\mathbf{g}_\theta : \mathbb{R}^k \rightarrow \mathbb{R}^d$ 给出条件均值， τ^2 给出条件噪声方差。生成时先抽取

¹ D. P. Kingma, M. Welling, *Auto-Encoding Variational Bayes* In arXiv preprint arXiv:1312.6114, 2013

$\mathbf{z} \sim p$, 再抽取独立的 $\boldsymbol{\eta} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}_d)$, 返回 $\mathbf{x} = \mathbf{g}_\theta(\mathbf{z}) + \tau\boldsymbol{\eta}$ 。只显示 $\mathbf{g}_\theta(\mathbf{z})$ 相当于显示条件均值, 不是从式 (29.3) 完整采样。

在线性情形 $\mathbf{g}_\theta(\mathbf{z}) = \mathbf{W}\mathbf{z} + \mathbf{b}$, 其中 $\mathbf{W} \in \mathbb{R}^{d \times k}$, 便回到第 26.2.2 节各向同性噪声模型。这里用 k 表示潜变量维数、 τ^2 表示噪声方差, 边缘分布仍然是高斯:

$$p_\theta(\mathbf{x}) = \mathcal{N}(\mathbf{x}; \mathbf{b}, \mathbf{W}\mathbf{W}^\top + \tau^2 \mathbf{I}_d).$$

后验也能由配平方得到。把对数联合分布中与 $\mathbf{z}$ 有关的二次项合并, 后验精度矩阵为 $\mathbf{I}_k + \tau^{-2}\mathbf{W}^\top\mathbf{W}$, 因而

$$\begin{aligned} \boldsymbol{\Sigma} &= (\mathbf{I}_k + \tau^{-2}\mathbf{W}^\top\mathbf{W})^{-1}, \\ \mathbf{m}(\mathbf{x}) &= \tau^{-2}\boldsymbol{\Sigma}\mathbf{W}^\top(\mathbf{x} - \mathbf{b}), \\ p_\theta(\mathbf{z} | \mathbf{x}) &= \mathcal{N}(\mathbf{z}; \mathbf{m}(\mathbf{x}), \boldsymbol{\Sigma}). \end{aligned} \quad (29.4)$$

非线性解码器可以产生弯曲、非高斯的观测分布, 但 $\|\mathbf{x} - \mathbf{g}_\theta(\mathbf{z})\|_2^2$ 通常不再是 $\mathbf{z}$ 的二次式, 解析边缘化与高斯后验随之消失。VAE 使用前文的近似推断处理这一计算困难, 并没有改变式 (29.2) 的概率定义。

示例 29.1 同一观测分布的潜变量解释 取 $Z \sim \mathcal{N}(0, 1), E \sim \mathcal{N}(0, 1)$ 且二者独立, 令 $X = 2Z + E$, 于是 $X \sim \mathcal{N}(0, 5)$ 。观测 $x = 2$ 后,

$$p(z | x = 2) \propto \exp\left[-\frac{1}{2}\{z^2 + (2 - 2z)^2\}\right] \propto \exp\left[-\frac{5}{2}(z - 0.8)^2\right].$$

后验因此为 $\mathcal{N}(0.8, 0.2)$ 。虽然 x 已知, z 仍不唯一, 因为观测还混入了独立噪声。这个不确定性将与 Flow 中唯一的逆像形成对照。


29.2.2 VAE 目标与摊销后验

式 (22.1) 已经给出一般 ELBO, 第 22.2.3 节说明了摊销推断和重参数化梯度。将联合分布 (29.2) 代入, 单个观测的证据下界具体成为


$$\begin{aligned} \mathcal{L}(\theta, \phi; \mathbf{x}) &= \mathbb{E}_{q_\phi(\mathbf{z} | \mathbf{x})}[\log p_\theta(\mathbf{x} | \mathbf{z})] \\ &\quad - \text{KL}(q_\phi(\mathbf{z} | \mathbf{x}) \| p(\mathbf{z})) \leq \log p_\theta(\mathbf{x}). \end{aligned} \quad (29.5)$$

编码器 (encoder) 给出的是 $q_\phi(\mathbf{z} | \mathbf{x})$ 的分布参数, 而不是生成模型中一条额外的反向边。本章按 VAE 惯例用 ϕ 统称共享编码器的权重, 对应第 22.2.3 节的 ω ; 随观测变化的均值、尺度是网络输出, 不是各样本分别训练的权重。模型参数 θ 则属于生成分布。图 29.1 把两套计算分开: 观测从先验和解码器生成, 编码器只服务于训练及观测后的近似推断。把两种箭头叠成一个有向环, 会混淆生成联合分布与推断程序。

生成：从先验出发



推断：给定一个观测



$$\text{ELBO} = \mathbb{E}_{q_\phi(\mathbf{z}|\mathbf{x})}[\log p_\theta(\mathbf{x}|\mathbf{z})] - D_{\text{KL}}(q_\phi(\mathbf{z}|\mathbf{x}) \| p(\mathbf{z}))$$

图 29.1 VAE 的生成与推断分工。上行实线表示先抽潜变量、再按 $p_\theta(\mathbf{x}|\mathbf{z})$ 抽观测的生成顺序；下行虚线表示用 $q_\phi(\mathbf{z}|\mathbf{x})$ 构造近似后验的推断顺序。编码器与解码器框内直接写出概率对象，底部公式带给出连接两条路径的 ELBO；两行不合并成同一个有向图。

常用编码器取对角高斯

$$q_\phi(\mathbf{z}|\mathbf{x}) = \mathcal{N}(\mathbf{z}; \mathbf{m}_\phi(\mathbf{x}), \text{diag}(\mathbf{s}_\phi^2(\mathbf{x}))),$$

其中每个 $s_{\phi,j}(\mathbf{x}) > 0$ 。网络可以输出对数方差以保证正性。对标准高斯先验，KL 项解析可得：

$$\text{KL}(q_\phi \| p) = \frac{1}{2} \sum_{j=1}^k (m_{\phi,j}^2 + s_{\phi,j}^2 - 1 - \log s_{\phi,j}^2). \quad (29.6)$$

这里省略了各分量对 $\mathbf{x}$ 的依赖。期望项用 $\mathbf{z} = \mathbf{m}_\phi(\mathbf{x}) + \mathbf{s}_\phi(\mathbf{x}) \odot \boldsymbol{\epsilon}$ 估计，其中 $\boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}_k)$ ， $\odot$ 表示逐元素乘法。如此便可沿第 22 章的路径导数对两组网络参数求梯度，无须对每个样本另解一个完整优化问题。

所谓“重构项”是条件对数似然，不是与分布无关的距离。式 (29.3) 给出

$$-\log p_\theta(\mathbf{x}|\mathbf{z}) = \frac{\|\mathbf{x} - \mathbf{g}_\theta(\mathbf{z})\|_2^2}{2\tau^2} + \frac{d}{2} \log(2\pi\tau^2). \quad (29.7)$$

只有固定 τ 时，最后一项才是训练常数。学习方差时把对数方差项删掉，会得到另一个目标，并可能让模型仅靠扩大方差减少平方误差的权重。对于二值观测 $x_j \in \{0, 1\}$ ，若解码器输出独立 Bernoulli 参数 $\pi_j(\mathbf{z})$ ，负对数似然则为

$$-\sum_{j=1}^d [x_j \log \pi_j(\mathbf{z}) + (1 - x_j) \log(1 - \pi_j(\mathbf{z}))].$$

这解释了交叉熵的来源。连续灰度值即使落在 $[0, 1]$ ，也不是 Bernoulli 随

机变量的取值；直接套用这个损失需要另行说明其代理目标含义。离散像素可以用类别质量函数，或对连续条件密度在量化区间内积分。

在例 29.1 中，让编码器恰好输出 $q(z | 2) = \mathcal{N}(0.8, 0.2)$ ，可以逐项复核 ELBO：

$$\begin{aligned}\mathbb{E}_q(2 - 2Z)^2 &= (2 - 1.6)^2 + 4(0.2) = 0.96, \\ \mathbb{E}_q \log p(2 | Z) &= -\frac{1}{2} \log(2\pi) - 0.48, \\ \text{KL}(q \| p) &= \frac{1}{2}(0.8^2 + 0.2 - 1 - \log 0.2).\end{aligned}$$

合计 $\mathcal{L} \approx -2.12366$ ，与 $\log \mathcal{N}(2; 0, 5) = -\frac{1}{2} \log(10\pi) - 0.4$ 相等。若编码器忽略 x 而总输出先验，ELBO 降为 $-\frac{1}{2} \log(2\pi) - 4 \approx -4.91894$ 。观测模型没有改变，下界变松来自推断分布没有跟上后验。

实际训练从一个小批量中取观测，编码器输出分布参数，为每个观测抽少量标准噪声，用式 (29.5) 的随机估计更新 θ 和 ϕ ，反复遍历数据直至达到预算或验证指标停止改善。若一次编码和一次解码的代价分别为 C_{enc} 和 C_{dec} ，每个观测使用一个潜变量样本时，前向计算约为 $O(C_{\text{enc}} + C_{\text{dec}} + k)$ ，反向传播通常为同阶；使用更多样本降低部分蒙特卡洛方差，但增加解码成本。无条件生成不需要编码器，观测后的快速近似推断则只运行编码器。

理解失败原因还要区分三个层次。**模型近似误差** (model approximation error) 来自候选 p_θ 本身不能充分表示数据分布；即使精确求解最大似然目标也不能消除它。固定模型参数后，限制近似后验的形状会造成**近似族误差** (variational approximation error)；同一族中，每个观测各自可选的最优参数又未必能由一个共享编码器同时给出，这部分是**摊销误差** (amortization error)。具体地，设 $\mathcal{Q}$ 为候选后验族，记 $\mathcal{L}_\mathcal{Q}^*(\mathbf{x}) = \sup_{q \in \mathcal{Q}} \mathcal{L}(\theta, q; \mathbf{x})$ ，且 $q_\phi(\cdot | \mathbf{x}) \in \mathcal{Q}$ ，则

$$\begin{aligned}\log p_\theta(\mathbf{x}) - \mathcal{L}(\theta, \phi; \mathbf{x}) &= [\log p_\theta(\mathbf{x}) - \mathcal{L}_\mathcal{Q}^*(\mathbf{x})] \\ &\quad + [\mathcal{L}_\mathcal{Q}^*(\mathbf{x}) - \mathcal{L}(\theta, \phi; \mathbf{x})].\end{aligned}\tag{29.8}$$

两项都非负。后一项对实际训练出的编码器还包含优化不足；只有像式 (22.18) 那样进一步比较最优共享编码器，才能把纯粹的摊销限制与优化误差分开。增加解码器容量、扩大后验族、改进编码器优化，分别作用于不同问题，不能彼此替代。

29.2.3 生成能力与失效模式

潜变量维度 k 影响模型把哪些变化交给 $\mathbf{z}$ 表示，但 $k < d$ 并不意味着观测必然没有 d 维密度。只要式 (29.3) 中的 $\tau > 0$ ，条件噪声就覆盖全部观测维度。若把噪声去掉，光滑低维解码器的输出才通常集中在低维集合上。增大 k 可以减轻表示瓶颈，也会增加需要学习和推断的自由度；它不保证所有潜变量都被使用。

当给定潜变量后仍有多种明显不同的观测可能，单一高斯条件分布可能把它们平均。对任意具有有限二阶矩的条件分布，恒等式

$$\begin{aligned}\mathbb{E}[\|\mathbf{X} - \mathbf{a}\|_2^2 | \mathbf{z}] &= \mathbb{E}[\|\mathbf{X} - \mathbb{E}[\mathbf{X} | \mathbf{z}]\|_2^2 | \mathbf{z}] \\ &\quad + \|\mathbb{E}[\mathbf{X} | \mathbf{z}] - \mathbf{a}\|_2^2\end{aligned}$$

说明平方损失的最优输出是条件均值。例如同一个位置的边缘等概率出现在左右两处，均值图像会同时保留两处较淡的边缘。这是“模糊重构”的一种机制，不是所有 VAE 必然模糊的定理。更有表达力的条件似然可以表示多种局部结果；从简单高斯额外抽噪声则只会加入该高斯所允许的变化，不能自动恢复缺失的结构。

另一种失败是编码几乎不再携带观测信息。本节用**后验坍塌**（posterior collapse）指编码器的近似后验接近先验，即 $q_\phi(\mathbf{z} | \mathbf{x}) \approx p(\mathbf{z})$ ；若只有部分坐标出现这种现象，则这些坐标对应的近似后验不再明显依赖观测。这一口径描述的是 q_ϕ ，不能直接据此判断生成模型的真实后验 $p_\theta(\mathbf{z} | \mathbf{x})$ 。前面的高斯例子已经给出对照：固定例 29.1 的生成模型，让编码器总输出先验，在 $x = 2$ 时真实后验仍为 $\mathcal{N}(0.8, 0.2)$ ，只是近似推断没有跟上它。

若解码器本身忽略全部潜变量，即 $p_\theta(\mathbf{x} | \mathbf{z}) = p_\theta(\mathbf{x})$ ，则真实后验也等于先验 $p(\mathbf{z})$ 。固定这一生成模型时，ELBO 在 $q_\phi(\mathbf{z} | \mathbf{x}) = p(\mathbf{z})$ 处达到最大。强大的解码器若能绕过潜变量解释数据，减少 KL 代价可能比利用潜变量更有利；优化过程也可能让模型过早进入这一状态。因此，编码器的 $\text{KL}(q_\phi \| p)$ 接近零可以作为坍塌线索，但不能单独证明解码器已忽略潜变量；它也不意味着所有生成能力都丧失了，因为解码器本身仍可能生成数据。

编码器在训练数据上使用的潜空间，与无条件生成时抽取的先验空间，也未必完全一致。定义**聚合后验**（aggregated posterior）

$$q_{\text{agg}}(\mathbf{z}) = \mathbb{E}_{\mathbf{X} \sim p_{\text{data}}} [q_\phi(\mathbf{z} | \mathbf{X})], \quad (29.9)$$

即把不同观测的编码分布按数据频率混合。假设相关 KL 有限，在 $\log(q_\phi/p)$ 中加減 $\log q_{\text{agg}}$ ，可得

$$\mathbb{E}_{p_{\text{data}}} \text{KL}(q_\phi(\mathbf{z} | \mathbf{X}) \| p(\mathbf{z})) = I_q(\mathbf{X}; \mathbf{Z}) + \text{KL}(q_{\text{agg}} \| p). \quad (29.10)$$

其中 I_q 是联合分布 $p_{\text{data}}(\mathbf{x})q_\phi(\mathbf{z} | \mathbf{x})$ 下的互信息。第一部分惩罚编码携带的数据信息，第二部分惩罚聚合后验偏离先验。因此，逐样本 KL 既不只是“让潜空间像高斯”，也不保证有限训练后两者完全相同。若先验在编码器很少访问的区域仍有明显质量，生成时就可能进入解码器缺少训练支持的区域。

常见修正应按改变的对象理解。把 KL 系数从小值逐渐提高到 1，改变

的是训练路径；若最终保持 $\lambda \neq 1$ ，优化的 $\mathbb{E}_q \log p_\theta(\mathbf{x} | \mathbf{z}) - \lambda \text{KL}(q \| p)$ 就不再是原始 ELBO。 $\lambda \geq 1$ 时它仍不大于原 ELBO， $\lambda < 1$ 时则没有相同的下界保证。限制解码器绕过潜变量的信息通路改变模型结构；使用更灵活的后验主要缩小推断差距；学习一个可评价密度的先验则改变生成模型及 KL 比较的对象。这些措施不提供无条件的防坍塌保证。

已有标签或其他条件 $\mathbf{c}$ 时，**条件 VAE** (conditional VAE) 把“要生成哪一类观测”直接交给模型，使用 $p_\theta(\mathbf{z} | \mathbf{c})p_\theta(\mathbf{x} | \mathbf{z}, \mathbf{c})$ 以及 $q_\phi(\mathbf{z} | \mathbf{x}, \mathbf{c})$ 。这时潜变量只需解释给定 $\mathbf{c}$ 之后剩余的变化。**层次 VAE** (hierarchical VAE) 则设置多层随机潜变量，例如 $p(\mathbf{z}_2)p_\theta(\mathbf{z}_1 | \mathbf{z}_2)p_\theta(\mathbf{x} | \mathbf{z}_1)$ ，让不同层分担不同依赖。它增加了模型的随机结构，同时也增加了后验的耦合；不是在确定性解码网络中多加几层就自动得到层次 VAE。

29.3 基于可逆变换的密度模型

29.3.1 变量变换与精确密度

VAE 的积分困难来自同一个观测可以由许多潜变量和观测噪声共同产生。如果让每个观测恰好对应一个基础变量，就可以用体积变化取代边缘化。**规范化流** (normalizing flow, Flow) 把一个可评价密度的基础分布经过一串可逆变换推送到数据空间，并在变换中追踪密度。这里沿用第 16 章的“规范化流”译名；文献也常称其为归一化流²。

设 $\mathbf{Z} \sim p_0$ ， $\mathbf{X} = f_\theta(\mathbf{Z})$ ， $\mathbf{z}, \mathbf{x}$ 均为 d 维。为使用通常的变量变换公式，一个充分条件是 f_θ 在相应开集间为连续可微双射，其逆连续可微，Jacobian 行列式非零。分段光滑网络可以允许零测集上的不可微点，但仍须满足几乎处处非奇异及变量变换所需的正则性；“几乎处处可微且双射”本身不足以排除奇异变换。记 $\mathbf{J}_f(\mathbf{z})$ 为 f 对 $\mathbf{z}$ 的 Jacobian 矩阵，有

$$\begin{aligned} p_\theta(\mathbf{x}) &= p_0(f_\theta^{-1}(\mathbf{x})) \left| \det \mathbf{J}_{f_\theta^{-1}}(\mathbf{x}) \right|, \\ \log p_\theta(\mathbf{x}) &= \log p_0(\mathbf{z}) - \log \left| \det \mathbf{J}_{f_\theta}(\mathbf{z}) \right|. \end{aligned} \quad (29.11)$$

这里 $\mathbf{z} = f_\theta^{-1}(\mathbf{x})$ 。理解行列式的作用，可以取基础空间中一个足够小的体积元：其像的体积约放大 $|\det \mathbf{J}_f|$ 倍，概率质量保持不变，密度就必须缩小相同倍数。对整个空间积分便恢复基础分布的总质量 1，不需要再估计一个配分函数。

若 $f = f_K \circ \dots \circ f_1$ ，令 $\mathbf{h}_0 = \mathbf{z}$ 、 $\mathbf{h}_\ell = f_\ell(\mathbf{h}_{\ell-1})$ 、 $\mathbf{h}_K = \mathbf{x}$ ，链式法则给出

$$\log p_\theta(\mathbf{x}) = \log p_0(\mathbf{h}_0) - \sum_{\ell=1}^K \log |\det \mathbf{J}_{f_\ell}(\mathbf{h}_{\ell-1})|. \quad (29.12)$$

训练时从数据逆行到基础变量，累积每层对数行列式，再对式 (29.1) 求梯

² G. Papamakarios, E. Nalisnick, D. J. Rezende, S. Mohamed, B. Lakshminarayanan, *Normalizing Flows for Probabilistic Modeling and Inference* In *Journal of Machine Learning Research*, 2021, vol. 22, no. 57, pp. 1–64

度；生成时从 p_0 抽样并正向通过各层。这些计算不含变分下界。但数学上存在逆函数，不等于逆函数计算便宜；一般稠密 $d \times d$ 矩阵用常规分解计算行列式要 $O(d^3)$ 运算，形成完整 Jacobian 本身也可能昂贵。可用的流结构必须同时控制逆变换和体积因子的成本。

示例 29.2 用缩放得到相同的一维密度 取 $Z \sim \mathcal{N}(0, 1)$ ，令 $X = \sqrt{5}Z$ ，同样得到 $\mathcal{N}(0, 5)$ 。给定 $x = 2$ ，唯一逆像是 $z = 2/\sqrt{5}$ ，因此

$$\log p(2) = -\frac{1}{2} \log(2\pi) - \frac{1}{2} (2/\sqrt{5})^2 - \log \sqrt{5} \approx -2.12366.$$

这与 VAE 例子的观测密度相同，但这里没有 $\mathcal{N}(0.8, 0.2)$ 那样的潜变量后验不确定性。两个生成机制可以定义同一个观测分布，观测似然无法单独识别哪个潜变量解释才是实际原因。

标准 Flow 要求基础空间与观测空间同维，因为上述 Jacobian 必须是同维变换的方阵。重排、分块输出和保留旁路变量可以改变中间张量形状，却没有丢弃总自由度。若真地丢弃一些坐标，就要对它们边缘化；若增加随机变量，则要说明扩展空间的联合密度。连续 Flow 处理离散观测也需要桥接：以单位宽度量化为例，对量化值 $\mathbf{y}$ ，离散质量是 $p(\mathbf{y}) = \int_{[0,1]^d} p_{\text{cont}}(\mathbf{y} + \mathbf{u}) d\mathbf{u}$ ，不是 $p_{\text{cont}}(\mathbf{y})$ 。取 $\mathbf{U}$ 在 $[0, 1]^d$ 上均匀分布，均匀去量化的 $\mathbb{E}_{\mathbf{U}} \log p_{\text{cont}}(\mathbf{y} + \mathbf{U})$ 由 Jensen 不等式给出该对数质量的下界；若还有缩放预处理，必须计入其 Jacobian。

29.3.2 可逆网络结构

让每层都具有容易计算的 Jacobian，可以在可逆性与非线性之间取得实际可用的折中。**仿射耦合层** (affine coupling layer) 把坐标分成两个非空、不相交的块 A, B ，保留一块，用它决定另一块的缩放和平移：

$$\begin{aligned} \mathbf{x}_A &= \mathbf{z}_A, \\ \mathbf{x}_B &= \mathbf{z}_B \odot \exp(\mathbf{a}_\theta(\mathbf{z}_A)) + \mathbf{b}_\theta(\mathbf{z}_A). \end{aligned} \tag{29.13}$$

指数逐元素作用，保证每个缩放因子为正。给定 $\mathbf{x}$ ，先恢复 $\mathbf{z}_A = \mathbf{x}_A$ ，再计算 $\mathbf{z}_B = (\mathbf{x}_B - \mathbf{b}_\theta(\mathbf{x}_A)) \odot \exp(-\mathbf{a}_\theta(\mathbf{x}_A))$ 。两个子网络本身都不要求可逆，因为它们的输入已经由保留块确定。Real NVP 以这类耦合变换构造密度模型³。

³ L. Dinh, J. Sohl-Dickstein, S. Bengio, *Density Estimation Using Real NVP* In International Conference on Learning Representations, 2017

按 A, B 的顺序排列坐标, Jacobian 为

$$\mathbf{J}_f = \begin{pmatrix} \mathbf{I} & \mathbf{0} \\ * & \text{diag}(\exp \mathbf{a}_\theta(\mathbf{z}_A)) \end{pmatrix}, \quad (29.14)$$

$$\log |\det \mathbf{J}_f| = \sum_{j=1}^{|B|} a_{\theta,j}(\mathbf{z}_A).$$

星号块包含复杂导数, 但三角矩阵的行列式不需要它。图 29.2 展示了这种安排为何能兼顾灵活子网络与简单逆变换。单层始终不改变 A 块, 表达能力有限; 多层之间交换分块或插入可逆混合, 才让不同坐标相互影响。若单层子网络代价为 C , 计算行列式的额外代价仅为 $O(d)$, K 层正向或逆向计算约需 $O(K(C + d))$, 这里不把子网络计算本身错误地算成线性成本。




图 29.2 仿射耦合层的计算依赖。粗线把 $\mathbf{z}_A$ 送入任意子网络, 该子网络只产生缩放和平移参数; 下方逐元素仿射变换才真正改变 $\mathbf{z}_B$ 。Jacobian 为下三角结构, 因此子网络不必可逆, 整层的对数行列式只需对缩放对数求和。逆向计算先恢复原样保留的 $\mathbf{z}_A$, 再撤销缩放和平移。

一个可复核的二维例子是 $x_1 = z_1$ 、 $x_2 = 2z_2 + z_1^2$ 。在 $\mathbf{z} = (1, -1)$ 处, $\mathbf{x} = (1, -1)$, 逆变换给出 $z_2 = (x_2 - x_1^2)/2 = -1$ 。Jacobian 为 $\begin{pmatrix} 1 & 0 \\ 2z_1 & 2 \end{pmatrix}$, 行列式恒为 2。若基础分布为二维标准高斯, 则该观测的对数密度为 $-\log(2\pi) - 1 - \log 2$; 非线性的 z_1^2 改变坐标关系, 却没有增加行列式的计算难度。

三角结构也可以逐坐标建立。**自回归流** (autoregressive flow) 利用前面的坐标决定当前的可逆变换。这里讨论的是变换方向的计算取舍, 不重述第 26 章的自回归建模。**掩码自回归流** (masked autoregressive flow, MAF) 的一种形式为

$$x_j = \mu_j(\mathbf{x}_{<j}) + \exp(a_j(\mathbf{x}_{<j}))z_j, \quad j = 1, \dots, d,$$

其中 $\mathbf{x}_{<j} = (x_1, \dots, x_{j-1})$ 。评价给定 $\mathbf{x}$ 时，所有条件输入已知，掩码网络可并行给出各 μ_j, a_j ，从而恢复 $\mathbf{z}$ 并求出三角 Jacobian 的行列式；生成时 $\mathbf{x}_{<j}$ 尚未齐备，必须顺序恢复坐标。

逆自回归流 (inverse autoregressive flow, IAF) 则把上式参数改成 $\mu_j(\mathbf{z}_{<j})$ 和 $a_j(\mathbf{z}_{<j})$ 。抽好全部基础噪声后，可以并行计算输出及这些新样本的密度；但对任意外部 $\mathbf{x}$ 求逆时，要逐坐标解出 $\mathbf{z}$ 。所以“采样后顺便计算其密度”与“对任意指定点计算密度”是不同任务。MAF 和 IAF 的方向取舍已在原始 MAF 论文中明确比较⁴。

还可以把许多离散层换成连续变换。**连续规范化流** (continuous normalizing flow, CNF) 用常微分方程

$$\frac{d\mathbf{h}_u}{du} = \mathbf{v}_\theta(\mathbf{h}_u, u), \quad 0 \leq u \leq 1,$$

定义从 $\mathbf{h}_0 = \mathbf{z}$ 到 $\mathbf{h}_1 = \mathbf{x}$ 的映射。这里 u 是变换参数，不是数据的真实时间。一个充分的正则设定是速度场对空间连续可微、具有足够的 Lipschitz 控制，并且解在整个区间正反两向都存在；唯一解使不同轨迹不能在同一 u 相交，从而定义可逆流。

记 ρ_u 为 $\mathbf{h}_u$ 的密度。小步映射的 Jacobian 为 $\mathbf{I} + \Delta u \mathbf{J}_\mathbf{v} + o(\Delta u)$ ，结合 $\log \det(\mathbf{I} + \Delta u \mathbf{A}) = \Delta u \operatorname{tr} \mathbf{A} + o(\Delta u)$ ，可从式 (29.11) 得到**瞬时变量变换公式** (instantaneous change of variables)：

$$\begin{aligned} \frac{d}{du} \log \rho_u(\mathbf{h}_u) &= -\nabla_{\mathbf{h}} \cdot \mathbf{v}_\theta(\mathbf{h}_u, u), \\ \log p_\theta(\mathbf{x}) &= \log p_0(\mathbf{z}) - \int_0^1 \nabla_{\mathbf{h}} \cdot \mathbf{v}_\theta(\mathbf{h}_u, u) du. \end{aligned} \quad (29.15)$$

散度 $\nabla \cdot \mathbf{v} = \sum_j \partial v_j / \partial h_j$ 就是 Jacobian 的迹，表示局部体积膨胀率。CNF 因而不必把每个有限层的 Jacobian 限制为三角形，却要反复求解速度场与散度。

高维时，迹仍可能昂贵。若 $\mathbb{E} \mathbf{r} = \mathbf{0}$ 且 $\mathbb{E} \mathbf{r} \mathbf{r}^\top = \mathbf{I}$ ，则 $\operatorname{tr} \mathbf{A} = \mathbb{E}_{\mathbf{r}}[\mathbf{r}^\top \mathbf{A} \mathbf{r}]$ ；自动微分可以通过向量与 Jacobian 的乘积估计它。FFJORD 将这种随机迹估计用于连续流⁵。

这个恒等式保证固定矩阵下的迹估计无偏，不意味着一次估计精确，也不消除数值求解误差。连续流的似然有精确的数学定义，程序返回的通常是积分和迹的数值近似；正向、逆向都需要求解器，成本取决于函数评价次数和场的数值性质。

29.3.3 生成模型与变分后验

规范化流不一定直接变换观测空间。作为独立生成模型，它变换 $\mathbf{z}$ 得到 $\mathbf{x}$ ，并通过式 (29.11) 计算观测密度。作为 VAE 的近似后验，它变换一个给定

⁴ G. Papamakarios, T. Pavlakou, I. Murray, *Masked Autoregressive Flow for Density Estimation* In arXiv preprint arXiv:1705.07057, 2017

⁵ W. Grathwohl, R. T. Q. Chen, J. Bettencourt, I. Sutskever, D. Duvenaud, *FFJORD: Free-form Continuous Dynamics for Scalable Reversible Generative Models* In arXiv preprint arXiv:1810.01367, 2018

$\mathbf{x}$ 的简单潜变量分布, 得到更复杂的 $q_\phi(\mathbf{z} | \mathbf{x})$ 。后者改变的是推断族, 生成联合分布 $p_\theta(\mathbf{x}, \mathbf{z})$ 可以保持原样⁶。

具体地, 先抽 $\mathbf{u} \sim q_0(\mathbf{u} | \mathbf{x})$, 再令 $\mathbf{z} = f_\phi(\mathbf{u}; \mathbf{x})$ 。只要求固定 $\mathbf{x}$ 时对 $\mathbf{u}$ 为合适的双射, 就有

$$\log q_\phi(\mathbf{z} | \mathbf{x}) = \log q_0(\mathbf{u} | \mathbf{x}) - \log \left| \det \frac{\partial f_\phi(\mathbf{u}; \mathbf{x})}{\partial \mathbf{u}^\top} \right|. \quad (29.16)$$

在 $\mathbb{E}_{q_\phi}[\log p_\theta(\mathbf{x}, \mathbf{z}) - \log q_\phi(\mathbf{z} | \mathbf{x})]$ 中代入该式即可训练。原先的对角高斯 KL 通常不再保留解析形式, 但联合密度与后验样本密度都可评价, 因而仍可作蒙特卡洛估计。训练只需评价自己刚生成的后验样本, 这也是 IAF 适合这一用途的原因。

更灵活的 q 可能收紧下界, 但没有把 VAE 观测边缘积分变成精确可解。反过来, 独立 Flow 中的 $\mathbf{z} = f^{-1}(\mathbf{x})$ 是唯一编码, 其条件分布是点质量, 不能套用连续非退化后验的直觉。标准光滑双射还保留支持集的某些拓扑性质: 全空间上正密度的基础分布经处处非奇异的满射变换后, 仍在全空间上为正, 不能精确变成只有两个分离支撑区域的密度。它可以把连接区域的概率压得很小, 但极端缩放可能带来较差的数值条件。精确变量变换解决了密度追踪问题, 没有取消模型结构和数值计算的约束。

29.4 扩散与分数生成模型

29.4.1 前向扰动与逆向生成

另一种构造分布的办法, 是把复杂生成拆成很多小步: 训练时观察数据如何逐渐受噪声扰动, 生成时学习沿相反方向移动。**扩散模型** (diffusion model) 用这种人为构造的随机过程连接数据与简单噪声。以下的 $\mathbf{x}_t$ 表示同一个观测在不同噪声尺度下的状态, t 不是第 28 章中设备运行或序列演化的真实时间。

去噪扩散概率模型 (denoising diffusion probabilistic model, DDPM) 的一种标准前向过程固定噪声日程 $0 < \beta_t < 1$, $t = 1, \dots, T$, 并定义

$$\begin{aligned} q(\mathbf{x}_{1:T} | \mathbf{x}_0) &= \prod_{t=1}^T q(\mathbf{x}_t | \mathbf{x}_{t-1}), \\ q(\mathbf{x}_t | \mathbf{x}_{t-1}) &= \mathcal{N}(\mathbf{x}_t; \sqrt{\alpha_t} \mathbf{x}_{t-1}, \beta_t \mathbf{I}_d), \\ \alpha_t &= 1 - \beta_t, \quad \bar{\alpha}_t = \prod_{s=1}^t \alpha_s, \quad \bar{\alpha}_0 = 1. \end{aligned} \quad (29.17)$$

⁶ D. Rezende, S. Mohamed, *Variational Inference with Normalizing Flows* In Proceedings of the 32nd International Conference on Machine Learning, 2015, pp. 1530–1538

信号每步缩小，同时加入独立高斯噪声。若上一步给定 $\mathbf{x}_0$ 的噪声方差为 $1 - \bar{\alpha}_{t-1}$ ，下一步就是 $\alpha_t(1 - \bar{\alpha}_{t-1}) + \beta_t = 1 - \bar{\alpha}_t$ 。由此归纳得到

$$\begin{aligned} q(\mathbf{x}_t | \mathbf{x}_0) &= \mathcal{N}(\mathbf{x}_t; \sqrt{\bar{\alpha}_t} \mathbf{x}_0, (1 - \bar{\alpha}_t) \mathbf{I}_d), \\ \mathbf{x}_t &= \sqrt{\bar{\alpha}_t} \mathbf{x}_0 + \sqrt{1 - \bar{\alpha}_t} \boldsymbol{\epsilon}, \quad \boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}_d). \end{aligned} \quad (29.18)$$

训练时因此可以直接抽取任意一步 $\mathbf{x}_t$ ，无须把前面所有噪声步骤都运行一遍。式中噪声表示这一步的合成噪声；它不意味着整条前向路径在各个 t 共用同一个独立噪声样本。上述构造及后续目标采用 DDPM 的固定日程设定⁷。

有限 T 下， $\bar{\alpha}_T > 0$ ，式 (29.18) 一般仍保留数据的均值、方差和高阶结构。取 $p(\mathbf{x}_T) = \mathcal{N}(\mathbf{0}, \mathbf{I}_d)$ 是模型的终端先验选择，不是声称前向终点与它无条件相等。对固定 $\mathbf{x}_0$ ，差距可精确写成

$$\begin{aligned} \text{KL}(q(\mathbf{x}_T | \mathbf{x}_0) \| p(\mathbf{x}_T)) \\ = \frac{1}{2} [\bar{\alpha}_T \|\mathbf{x}_0\|_2^2 - d\bar{\alpha}_T - d \log(1 - \bar{\alpha}_T)]. \end{aligned} \quad (29.19)$$

若数据二阶矩有限，且日程使 $\bar{\alpha}_T \rightarrow 0$ ，这个量的数据平均趋于零，并由 KL 的凸性控制前向边缘 q_T 与终端先验的 KL。有限步时是否足够接近，要结合数据尺度、维度和日程判断，不能仅凭“步数很多”下结论。

在贯穿例子 $X_0 \sim \mathcal{N}(0, 5)$ 中，前向边缘可以直接算出：

$$q_t(x) = \mathcal{N}(x; 0, 1 + 4\bar{\alpha}_t). \quad (29.20)$$

若 $\bar{\alpha}_T = 0.25$ ，终点是 $\mathcal{N}(0, 2)$ 而非 $\mathcal{N}(0, 1)$ ，两者 KL 为 $\frac{1}{2}(2 - 1 - \log 2) \approx 0.15343$ ；若 $\bar{\alpha}_T = 0.01$ ，方差为 1.04，KL 降至约 0.000390。这是边缘 q_T 的 KL，与式 (29.19) 中给定某个 $\mathbf{x}_0$ 的条件 KL 不同，后者平均后通常更大。

逆向生成从终端先验抽样，再逐步生成较低噪声状态：

$$\begin{aligned} p_\theta(\mathbf{x}_{0:T}) &= p(\mathbf{x}_T) \prod_{t=1}^T p_\theta(\mathbf{x}_{t-1} | \mathbf{x}_t), \\ p_\theta(\mathbf{x}_0) &= \int p_\theta(\mathbf{x}_{0:T}) d\mathbf{x}_{1:T}. \end{aligned} \quad (29.21)$$

各转移和终端先验归一化即可保证联合与边缘归一化。中间状态是与观测同维的潜变量，因此离散扩散也属于有向潜变量模型；特殊之处在于前向推断路径由固定扰动规则给定，而不是为每个样本训练一个 VAE 式编码器。

图 29.3 中的逆转移通常用神经网络参数化高斯均值及方差。这里有一个重要边界：对一般数据，真实 $q(\mathbf{x}_{t-1} | \mathbf{x}_t)$ 是对未知 $\mathbf{x}_0$ 混合后的分布，不保证为高斯。小步高斯逆转移是有限步模型的参数化选择；下面可解析的

⁷ J. Ho, A. N. Jain, P. Abbeel, *De-noising Diffusion Probabilistic Models* In *Advances in Neural Information Processing Systems*, 2020

前向 q : t 递增



逆向 p_θ : t 递减



图 29.3 离散扩散的两条条件化链。上行是训练时固定的加噪过程，下行是从终端先验开始的生成过程；方框用逐渐加深的灰度和“清晰—轻噪—近纯噪”文字显示样本随 t 变化。相同下标表示相同噪声尺度，不表示两行抽样路径逐点相同；有限 T 时 $q_T \approx p(x_T)$ 需要日程与数据尺度支持。

高斯是额外给定 $\mathbf{x}_0$ 的 $q(\mathbf{x}_{t-1} | \mathbf{x}_t, \mathbf{x}_0)$ 。二者不可混同。

29.4.2 变分目标与分数匹配

为了学习式 (29.21)，把整条 $\mathbf{x}_{1:T}$ 路径视为潜变量，固定 $\mathbf{x}_0$ 后应用式 (22.1)。这里的观测是 $\mathbf{x}_0$ ，一般公式中的 $\mathbf{z}$ 则由整条加噪路径代替。记 $\mathcal{B}_{\text{diff}}(\mathbf{x}_0)$ 为路径下界，负下界为 $\mathcal{J}_{\text{diff}} = -\mathcal{B}_{\text{diff}}$ ，则

$$\begin{aligned} \log p_\theta(\mathbf{x}_0) &\geq \mathcal{B}_{\text{diff}}(\mathbf{x}_0), \\ \mathcal{J}_{\text{diff}}(\mathbf{x}_0) &= \mathbb{E}_{q(\mathbf{x}_{1:T}|\mathbf{x}_0)} \left[\log \frac{q(\mathbf{x}_{1:T} | \mathbf{x}_0)}{p_\theta(\mathbf{x}_{0:T})} \right]. \end{aligned} \quad (29.22)$$

要把这个路径比值化为局部计算，使用 $t \geq 2$ 时的 Bayes 恒等式

$$q(\mathbf{x}_t | \mathbf{x}_{t-1}) = q(\mathbf{x}_{t-1} | \mathbf{x}_t, \mathbf{x}_0) \frac{q(\mathbf{x}_t | \mathbf{x}_0)}{q(\mathbf{x}_{t-1} | \mathbf{x}_0)}.$$

代入前向连乘，右侧的边缘比值逐项消去，留下 $q(\mathbf{x}_T | \mathbf{x}_0) \prod_{t=2}^T q(\mathbf{x}_{t-1} | \mathbf{x}_t, \mathbf{x}_0)$ 。对每个 $\mathbf{x}_{t-1}$ 先取条件期望，就得到

$$\begin{aligned} \mathcal{J}_{\text{diff}}(\mathbf{x}_0) &= \text{KL}(q(\mathbf{x}_T | \mathbf{x}_0) \| p(\mathbf{x}_T)) \\ &\quad + \sum_{t=2}^T \mathbb{E}_{q(\mathbf{x}_t|\mathbf{x}_0)} \text{KL}(q(\mathbf{x}_{t-1} | \mathbf{x}_t, \mathbf{x}_0) \| p_\theta(\mathbf{x}_{t-1} | \mathbf{x}_t)) \\ &\quad - \mathbb{E}_{q(\mathbf{x}_1|\mathbf{x}_0)} \log p_\theta(\mathbf{x}_0 | \mathbf{x}_1). \end{aligned} \quad (29.23)$$

三部分分别是终点匹配、逐步逆转移匹配和观测解码。固定日程与先验时，第一项对 θ 是常数，可以在求梯度时省略，却不能在报告似然界时删掉。最后一项不是 $t = 1$ 的普通高斯 KL，因为给定 $\mathbf{x}_0$ 时它已经是观测值，不

是一个具有正方差的待积分变量。

中间 KL 之所以可计算，是因为前向过程给定 $\mathbf{x}_0$ 后全为高斯。对 $t \geq 2$ ，将 $q(\mathbf{x}_t | \mathbf{x}_{t-1})q(\mathbf{x}_{t-1} | \mathbf{x}_0)$ 中关于 $\mathbf{x}_{t-1}$ 的平方项相加，其精度系数为

$$\frac{\alpha_t}{\beta_t} + \frac{1}{1 - \bar{\alpha}_{t-1}} = \frac{1 - \bar{\alpha}_t}{\beta_t(1 - \bar{\alpha}_{t-1})}.$$

线性项相应为 $\sqrt{\alpha_t}\mathbf{x}_t/\beta_t + \sqrt{\bar{\alpha}_{t-1}}\mathbf{x}_0/(1 - \bar{\alpha}_{t-1})$ 。乘上精度的倒数，使得

$$\begin{aligned} q(\mathbf{x}_{t-1} | \mathbf{x}_t, \mathbf{x}_0) &= \mathcal{N}(\mathbf{x}_{t-1}; \tilde{\boldsymbol{\mu}}_t, \tilde{\beta}_t \mathbf{I}_d), \\ \tilde{\beta}_t &= \frac{\beta_t(1 - \bar{\alpha}_{t-1})}{1 - \bar{\alpha}_t}, \\ \tilde{\boldsymbol{\mu}}_t &= \frac{\sqrt{\bar{\alpha}_{t-1}}\beta_t}{1 - \bar{\alpha}_t}\mathbf{x}_0 + \frac{\sqrt{\alpha_t}(1 - \bar{\alpha}_{t-1})}{1 - \bar{\alpha}_t}\mathbf{x}_t. \end{aligned} \quad (29.24)$$

学习时 $\mathbf{x}_0$ 已知，所以它可以出现在监督目标里；生成时未知，模型均值只能依赖当前 $\mathbf{x}_t$ 、噪声步 t 和允许使用的外部条件。

现固定逆方差 $\sigma_t^2 > 0$ ，令 $p_\theta(\mathbf{x}_{t-1} | \mathbf{x}_t) = \mathcal{N}(\boldsymbol{\mu}_\theta(\mathbf{x}_t, t), \sigma_t^2 \mathbf{I}_d)$ 。高斯 KL 分为均值误差与方差误差：

$$\begin{aligned} \text{KL}(q \| p_\theta) &= \frac{\|\tilde{\boldsymbol{\mu}}_t - \boldsymbol{\mu}_\theta(\mathbf{x}_t, t)\|_2^2}{2\sigma_t^2} + C_t, \\ C_t &= \frac{d}{2} \left(\frac{\tilde{\beta}_t}{\sigma_t^2} - 1 + \log \frac{\sigma_t^2}{\tilde{\beta}_t} \right). \end{aligned} \quad (29.25)$$

固定 σ_t^2 时 C_t 不依赖参数。常用选择包括 $\sigma_t^2 = \beta_t$ 和 $t \geq 2$ 时的 $\sigma_t^2 = \tilde{\beta}_t$ 。若学习逆方差，则均值误差的权重和方差项都要参与优化，不能把后者当成常数；若方差只依赖 $\mathbf{x}_t$ 而没有待学习参数，方差项虽仍对参数不变，也不再是仅依赖 t 的常数。

利用式 (29.18) 把 $\mathbf{x}_0$ 换成 $\mathbf{x}_t$ 和噪声，后验均值也可写成

$$\tilde{\boldsymbol{\mu}}_t = \frac{1}{\sqrt{\alpha_t}} \left(\mathbf{x}_t - \frac{\beta_t}{\sqrt{1 - \bar{\alpha}_t}} \boldsymbol{\epsilon} \right).$$

因此可以让网络预测合成噪声 $\boldsymbol{\epsilon}_\theta(\mathbf{x}_t, t)$ ，再定义

$$\boldsymbol{\mu}_\theta(\mathbf{x}_t, t) = \frac{1}{\sqrt{\alpha_t}} \left(\mathbf{x}_t - \frac{\beta_t}{\sqrt{1 - \bar{\alpha}_t}} \boldsymbol{\epsilon}_\theta(\mathbf{x}_t, t) \right). \quad (29.26)$$

两均值相减时 $\mathbf{x}_t$ 项抵消。记 $\ell_t(\theta)$ 为第 t 个中间 KL 的数据与扰动平均，并

仍按式 (29.18) 抽取 $\mathbf{x}_t$, 则

$$\begin{aligned}\ell_t(\theta) &= w_t \mathbb{E}_{\mathbf{x}_0, \epsilon} \|\epsilon - \epsilon_\theta(\mathbf{x}_t, t)\|_2^2 + C_t, \\ w_t &= \frac{\beta_t^2}{2\sigma_t^2 \alpha_t (1 - \bar{\alpha}_t)}, \quad t = 2, \dots, T.\end{aligned}\quad (29.27)$$

这才是固定逆方差、噪声参数化下的 ELBO 去噪权重。权重不是可随意丢弃的全局比例因子, 因为它一般随 t 变化。

示例 29.3 核对一个扩散步的权重 为方便计算, 人为取 $\beta_1 = 0.2$ 、 $\beta_2 = 0.25$, 于是 $\alpha_2 = 0.75$ 、 $\bar{\alpha}_1 = 0.8$ 、 $\bar{\alpha}_2 = 0.6$ 。在 $t = 2$ 时, $\tilde{\beta}_2 = 0.25(0.2)/0.4 = 0.125$ 。若 $\sigma_2^2 = 0.25$, 则 $w_2 = 0.25^2/(2 \cdot 0.25 \cdot 0.75 \cdot 0.4) = 5/12$ 。一维噪声预测误差为 0.3 时, 均值差的平方为

$$\frac{0.25^2}{0.75 \cdot 0.4} (0.3)^2 = 0.01875,$$

除以 $2\sigma_2^2 = 0.5$ 得到 0.0375, 恰等于 $(5/12)(0.3)^2$ 。完整 KL 还须加 $C_2 = \frac{1}{2}(0.5 - 1 + \log 2) \approx 0.09657$ 。这里的大噪声步只用于代数核, 不代表推荐训练日程。

DDPM 常用的简化目标则去掉逐步权重。独立抽取 $t \sim \text{Unif}\{1, \dots, T\}$ 、 $\mathbf{x}_0 \sim p_{\text{data}}$ 和 $\epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I}_d)$, 目标为

$$\mathcal{J}_{\text{simple}} = \mathbb{E}_{t, \mathbf{x}_0, \epsilon} \|\epsilon - \epsilon_\theta(\mathbf{x}_t, t)\|_2^2. \quad (29.28)$$

它去掉了式 (29.27) 的逐步权重, 并对 $t = 1$ 也使用噪声回归。因而其数值不是原始负 ELBO, 负值也不能直接作为对数似然下界报告。原始 DDPM 对离散像素采用量化区间积分作为解码质量, 简化损失并不等于这个精确解码项; 对连续数据使用固定方差高斯解码时, 解码负对数似然可换成带特定权重的平方误差, 但去掉权重依然改变目标⁸。

若要随机抽步但仍优化严格 ELBO, 可令 $t \in \{2, \dots, T\}$ 按概率 $\pi_t > 0$ 抽取, 用 $w_t \|\epsilon - \epsilon_\theta\|_2^2 / \pi_t$ 无偏估计中间项中依赖参数的部分, 并单独处理解码项。均匀抽步时补上步数因子即可; 若要报告完整界值, 还须计入 C_t 及终点项。改变抽样概率并做重要性校正, 改变的是估计方差; 不做校正而改变步权重, 改变的才是优化准则。对无限表达能力且各噪声尺度可独立拟合的理想模型, 正权重不改变每步平方回归的最优条件均值; 对共享有限网络, 各步竞争同一组参数, 权重会影响实际折中。

噪声回归还给出另一种解释。记 $q_t(\mathbf{x})$ 为前向扰动后的边缘密度, 其分数 (score) 是 $\mathbf{s}_t^*(\mathbf{x}) = \nabla_{\mathbf{x}} \log q_t(\mathbf{x})$, 表示密度沿各坐标增加的局部方向, 而不是分类分数。为与前向路径 q 保持一致, 本章写 q_t ; 许多分数模型文

⁸ J. Ho, A. N. Jain, P. Abbeel, *Denosing Diffusion Probabilistic Models* In *Advances in Neural Information Processing Systems*, 2020

献把同一个前向边缘记作 p_t 。高斯扰动的条件分数已知：

$$\nabla_{\mathbf{x}_t} \log q(\mathbf{x}_t | \mathbf{x}_0) = -\frac{\mathbf{x}_t - \sqrt{\bar{\alpha}_t} \mathbf{x}_0}{1 - \bar{\alpha}_t} = -\frac{\boldsymbol{\epsilon}}{\sqrt{1 - \bar{\alpha}_t}}.$$

若可以交换微分与积分，对 $q_t(\mathbf{x}_t) = \int q(\mathbf{x}_t | \mathbf{x}_0) p_{\text{data}}(\mathbf{x}_0) d\mathbf{x}_0$ 求导并除以 $q_t(\mathbf{x}_t) > 0$ ，得到

$$\mathbf{s}_t^*(\mathbf{x}_t) = \mathbb{E}[\nabla_{\mathbf{x}_t} \log q(\mathbf{x}_t | \mathbf{X}_0) | \mathbf{x}_t] = -\frac{\mathbb{E}[\boldsymbol{\epsilon} | \mathbf{x}_t]}{\sqrt{1 - \bar{\alpha}_t}}. \quad (29.29)$$

平方回归的最优预测就是条件均值，因而令 $\mathbf{s}_\theta = -\boldsymbol{\epsilon}_\theta / \sqrt{1 - \bar{\alpha}_t}$ ，噪声回归便在估计各尺度的边缘分数，并不是恢复每个样本唯一的“真实噪声”。

去噪分数匹配 (denoising score matching, DSM) 用已知扰动核的条件分数作为训练目标，学习未知边缘分数。更精确地，令 $\mathbf{a} = \nabla_{\mathbf{x}_t} \log q(\mathbf{x}_t | \mathbf{X}_0)$ ，由条件期望的正交分解，在平方矩有限时

$$\mathbb{E}\|\mathbf{s}_\theta - \mathbf{a}\|_2^2 = \mathbb{E}\|\mathbf{s}_\theta - \mathbf{s}_t^*\|_2^2 + \mathbb{E}\|\mathbf{a} - \mathbf{s}_t^*\|_2^2. \quad (29.30)$$

最后一项与网络无关，这给出了去噪训练能够学习边缘分数的依据。对于当前高斯核，噪声平方误差等于 $(1 - \bar{\alpha}_t)$ 乘以条件分数平方误差。因此简化噪声损失对应一种 DSM 尺度加权，严格 ELBO 对应另一种加权；任意正权重 DSM 不自动成为同一个生成模型的 ELBO。连续时间分数建模将这些噪声尺度连成一个共同框架⁹。

把式 (29.26) 改用分数表示，还得到

$$\boldsymbol{\mu}_\theta(\mathbf{x}_t, t) = \frac{\mathbf{x}_t + \beta_t \mathbf{s}_\theta(\mathbf{x}_t, t)}{\sqrt{\bar{\alpha}_t}}.$$

若分数精确，它给出真实逆转移的条件均值，但没有证明逆转移整体为高斯。在式 (29.20) 的例子中， $\mathbf{s}_t^*$ 的一维形式为 $-x_t / (1 + 4\bar{\alpha}_t)$ ，所以读者可直接把它代入检验均值。与第 27 章相连，若 $q_t(\mathbf{x}) \propto \exp[-E_t(\mathbf{x})]$ ，则 $\mathbf{s}_t^* = -\nabla E_t$ ，归一化常数在求导后消失。但一般向量网络不必恰好是某个标量能量的梯度；给出分数近似，不等于已经提供可直接评价的归一化密度。

算法 29.1 给出一个具体的连续观测版本：所有 $\sigma_t^2 > 0$ 都预先固定，均值均由式 (29.26) 给出，包括 $t = 1$ 的高斯解码分布 $p_\theta(\mathbf{x}_0 | \mathbf{x}_1)$ 。因此解码器没有独立于噪声网络、却又未被损失训练的参数。

⁹ Y. Song, J. Sohl-Dickstein, D. P. Kingma, A. Kumar, S. Ermon, B. Poole, *Score-Based Generative Modeling through Stochastic Differential Equations* In International Conference on Learning Representations, 2021

算法 29.1 固定方差 DDPM 的学习与祖先采样

输入： 连续观测数据集、固定 $\beta_{1:T}$ 及正的逆转移方差 $\sigma_{1:T}^2$

输出： 学得的噪声网络与模型样本

```

1: 初始化  $\theta$ , 预计算  $\alpha_t, \bar{\alpha}_t$ 
2: for 每个训练小批量, 直至停止条件满足 do
3:   为每个观测抽  $t \sim \text{Unif}\{1, \dots, T\}$  和标准高斯  $\epsilon$ 
4:   按式 (29.18) 计算  $\mathbf{x}_t$ 
5:   由式 (29.28) 更新参数
6: end for
7: 抽  $\mathbf{x}_T \sim \mathcal{N}(\mathbf{0}, \mathbf{I}_d)$ 
8: for  $t = T, T-1, \dots, 2$  do
9:   用噪声网络和式 (29.26) 计算  $\mu_\theta$ 
10:  独立抽  $\xi_t \sim \mathcal{N}(\mathbf{0}, \mathbf{I}_d)$ , 令  $\mathbf{x}_{t-1} = \mu_\theta + \sigma_t \xi_t$ 
11: end for
12: 抽  $\mathbf{x}_0 \sim p_\theta(\mathbf{x}_0 | \mathbf{x}_1)$  并返回

```

算法 29.1 明确使用简化训练损失；若目标是严格变分学习，应替换相应训练步骤并保留解码项。对连续高斯解码， σ_1^2 须单独取正值，不能把 $\tilde{\beta}_1 = 0$ 代入非退化高斯密度。有些生成程序在最后一步直接输出预测均值，这是一种确定性末步约定，并非对正方差解码分布的完整采样。若一次网络前向代价为 C_{net} ，抽步训练的单样本前向代价约为 $O(C_{\text{net}} + d)$ ，而完整 T 步祖先采样约为 $O(T(C_{\text{net}} + d))$ 。采样只需保留当前状态，不必保存整条路径；若要评价全路径变分界，则还需处理所有项或使用带校正的随机估计。

29.4.3 连续时间表示与采样

当噪声步变得足够细，可以把人工噪声索引写成连续 $t \in [0, T_c]$ ，其中 T_c 为连续过程的终点。为避免隐藏额外导数项，下面只讨论扩散系数依赖 t 、不依赖状态的各向同性情形。设 $\mathbf{W}_t$ 为 d 维标准**布朗运动** (Brownian motion)：不相交时间区间上的增量相互独立，长度为 Δt 的增量服从 $\mathcal{N}(\mathbf{0}, \Delta t \mathbf{I}_d)$ 。前向**随机微分方程** (stochastic differential equation, SDE) 为

$$d\mathbf{X}_t = \mathbf{b}(\mathbf{X}_t, t) dt + g(t) d\mathbf{W}_t, \quad \mathbf{X}_0 \sim p_{\text{data}}. \quad (29.31)$$

其中漂移 $\mathbf{b}$ 规定确定性的局部移动， $g(t) > 0$ 规定噪声强度。本节假设系数连续， $\mathbf{b}$ 对空间全局 Lipschitz 且至多线性增长， g 有界并在所讨论的闭区间上有正下界，以保证前向解存在且不爆炸。使用反向密度公式时，进一步假设 $q_t > 0$ ，对时间一阶、对空间二阶连续可微，在所用时间区间上 $\int \mathbb{E}_{q_t} \|\nabla \log q_t(\mathbf{X}_t)\|_2^2 dt < \infty$ ，并且反向方程存在不爆炸的解。若数据本身奇异，这些密度条件可以只在 $t \geq \delta > 0$ 的已加噪区间成立，不能默认 $t = 0$ 也有光滑密度。

与离散 DDPM 对应的方差保持过程取 $\mathbf{b}(\mathbf{x}, t) = -\frac{1}{2}\beta(t)\mathbf{x}$ 、 $g(t) = \sqrt{\beta(t)}$ 。其条件均值衰减系数为 $\exp[-\frac{1}{2}\int_0^t \beta(s)ds]$ ，条件方差为 $1 - \exp[-\int_0^t \beta(s)ds]$ 。因此只要有限 T_c 内积分有限，终点一般仍只是接近标准高斯；连续时间本身没有消除终点近似。

在这种条件扰动核可解析的设定中，训练可以从连续区间抽取 t ，构造 $\mathbf{x}_t$ ，再拟合条件分数 $\nabla_{\mathbf{x}_t} \log q(\mathbf{x}_t | \mathbf{x}_0)$ 。式 (29.29) 与式 (29.30) 对每个 $t > 0$ 仍然适用。时间抽样密度与损失权重共同决定各噪声尺度的训练比重；这仍是去噪分数学习，不能仅因把时间变成连续就将其数值解释为观测似然。

记真分数为 $\mathbf{s}_t^* = \nabla_{\mathbf{x}} \log q_t$ 。在上述正则条件及反向过程存在的设定下，反向 SDE 可以沿同一个 t 写成

$$\begin{aligned} d\mathbf{X}_t &= [\mathbf{b}(\mathbf{X}_t, t) - g(t)^2 \mathbf{s}_t^*(\mathbf{X}_t)] dt \\ &\quad + g(t) d\overline{\mathbf{W}}_t, \quad t : T_c \downarrow 0. \end{aligned} \quad (29.32)$$

这里 $dt < 0$ ，反向布朗增量的协方差是 $|dt|\mathbf{I}_d$ 。不能把括号里的漂移原样拿去按正时间步长运行。为消除实现上的符号歧义，令 $u = T_c - t$ 、 $\mathbf{Y}_u = \mathbf{X}_{T_c-u}$ ，则按递增 u 运行的等价形式是

$$\begin{aligned} d\mathbf{Y}_u &= -\mathbf{b}(\mathbf{Y}_u, T_c - u) du \\ &\quad + g(T_c - u)^2 \mathbf{s}_{T_c-u}^*(\mathbf{Y}_u) du \\ &\quad + g(T_c - u) d\mathbf{B}_u. \end{aligned} \quad (29.33)$$

其中 $\mathbf{B}_u$ 是按递增 u 定义的标准布朗运动。这是真分数下的时间反演结果；其一般证明需要随机过程的反演理论，这里采用已有结果，不把仅验证边缘方程充作路径反演的完整证明。分数 SDE 框架给出了该公式及更一般的状态相关扩散版本；后一种情形还会出现扩散矩阵的空间导数，不能直接照搬本式¹⁰。

式 (29.33) 也给出明确的数值一步。令 $t = T_c - u$ 、 $\Delta u > 0$ ，用学得分数替代真分数的 Euler-Maruyama 更新为

$$\begin{aligned} \mathbf{y}_{u+\Delta u} &= \mathbf{y}_u - \mathbf{b}(\mathbf{y}_u, t) \Delta u \\ &\quad + g(t)^2 \mathbf{s}_\theta(\mathbf{y}_u, t) \Delta u + g(t) \sqrt{\Delta u} \boldsymbol{\xi}, \end{aligned}$$

其中 $\boldsymbol{\xi} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}_d)$ ，每步独立抽取。漂移中的分数项为正号，使用真分数时该项沿密度增加的方向移动；这个正号与式 (29.32) 中的负号并不矛盾，两式使用的时间方向不同。要精确恢复前向数据分布，还必须从真实 q_{T_c} 启动并精确求解；换成简单终端先验、估计分数和离散求解都会引入各自的误差。

是否每次采样都必须在途中加入随机噪声？在真分数可得理想条件

¹⁰ Y. Song, J. Sohl-Dickstein, D. P. Kingma, A. Kumar, S. Ermon, B. Poole, *Score-Based Generative Modeling through Stochastic Differential Equations* In International Conference on Learning Representations, 2021

下，可以构造与前向 SDE 具有相同各时刻边缘密度的确定性方程。**概率流常微分方程** (probability flow ordinary differential equation, probability flow ODE) 定义速度

$$\frac{d\mathbf{X}_t}{dt} = \mathbf{v}^*(\mathbf{X}_t, t), \quad \mathbf{v}^*(\mathbf{x}, t) = \mathbf{b}(\mathbf{x}, t) - \frac{1}{2}g(t)^2\mathbf{s}_t^*(\mathbf{x}). \quad (29.34)$$

它不是简单地删除逆 SDE 的噪声项，分数系数还必须从 1 改成 1/2。给定终点后，ODE 轨迹确定；不同样本的随机性来自不同的终点抽样。

这个系数可以由密度守恒推导。前向 SDE 的 Fokker-Planck 方程为

$$\partial_t q_t = -\nabla \cdot (\mathbf{b}q_t) + \frac{1}{2}g(t)^2\Delta q_t.$$

利用 $q_t\mathbf{s}_t^* = \nabla q_t$ 以及 g 不依赖 $\mathbf{x}$ ，右侧等于

$$-\nabla \cdot \left[\left(\mathbf{b} - \frac{1}{2}g(t)^2\mathbf{s}_t^* \right) q_t \right],$$

这正是速度场 $\mathbf{v}^*$ 的连续性方程。在适当边界衰减、共同初始密度及密度方程唯一性条件下，ODE 与 SDE 具有相同的单时刻边缘。这个推导没有声称它们的多时刻联合分布或单条轨迹相同：随机扩散路径与确定性流路径本来就是不同的对象。

令 $\mathbf{v}_\theta = \mathbf{b} - \frac{1}{2}g^2\mathbf{s}_\theta$ ，并给 ODE 指定可评价密度的终端先验 p_{T_c} 。若这一速度场生成正反均存在的可微流，便独立定义了一个 ODE 密度模型 p_θ^{ODE} 。将式 (29.15) 沿数据到终点的方向积分，得到

$$\begin{aligned} \log p_\theta^{\text{ODE}}(\mathbf{x}_0) &= \log p_{T_c}(\mathbf{x}_{T_c}) + \int_0^{T_c} \nabla_{\mathbf{x}} \cdot \mathbf{v}_\theta(\mathbf{x}_t, t) dt, \\ \frac{d\mathbf{x}_t}{dt} &= \mathbf{v}_\theta(\mathbf{x}_t, t), \quad \mathbf{x}_{t=0} = \mathbf{x}_0. \end{aligned} \quad (29.35)$$

积分前面是正号，因为瞬时公式给出的是终点对数密度减去起点对数密度等于负散度积分，现在求解的是起点密度。评价似然时从数据向噪声积分，生成时从终端向数据积分；二者使用同一速度场和相反的积分方向。

例如一维速度 $v(x, t) = ax$ 、 $T_c = 1$ 、终端密度 $\mathcal{N}(0, 1)$ 时， $x_1 = e^a x_0$ ，散度积分为 a ，所以

$$\log p^{\text{ODE}}(x_0) = -\frac{1}{2} \log(2\pi) - \frac{1}{2}e^{2a}x_0^2 + a.$$

这恰是 $\mathcal{N}(0, e^{-2a})$ 的对数密度。取 $a = -\frac{1}{2} \log 5$ ，又得到贯穿例子的 $\mathcal{N}(0, 5)$ ；若把式 (29.35) 的积分符号写反，归一化因子就会出错。这个线性场仅用来核对变量变换，不假定它就是前述方差保持 SDE 的概率流。

“ODE 可以计算似然”必须带上模型对象和数值条件。近似分数代入 ODE 后，式 (29.35) 仍是该 ODE 所定义分布的密度公式，但一般不等于使

用同一近似分数的随机 SDE 分布，更不自动等于某个有限步 DDPM 的边缘似然。真分数、正确终点与精确积分时的同边缘结论，不能无条件转移给三个近似实现。

数值评价还需要沿轨迹计算散度。使用随机向量估计 $\nabla \cdot \mathbf{v}_\theta$ 时会有蒙特卡洛误差；有限容差的 ODE 求解器会产生轨迹与积分误差，二者的数值耦合也不能用迹估计无偏一句话消除。若只积分到 $\delta > 0$ ，得到的是该截断模型在 δ 处的密度，还需说明从 δ 到观测空间的解码或近似。对离散像素报告似然，另须统一去量化与测度约定。改善求解器容差不能修复分数偏差，增加迹样本也不能消除终点先验失配。

采样速度应以网络函数评价次数而非仅以“步数”衡量。一个高阶 ODE 步骤可能多次调用网络；自适应求解器还可能拒绝某次试步。随机采样允许每步注入噪声，确定性采样便于固定终点后的重复生成和编码，但在近似网络与有限预算下，二者不存在脱离设定的质量排序。减少离散步数通常降低计算，却改变数值误差；若原本讨论的就是有限步 DDPM，完整执行其每个转移是从该离散模型采样，跳过转移则定义了另一套采样近似。

采样蒸馏 (sampling distillation) 进一步用一个已训练采样器的多步输出监督另一个少步模型。渐进蒸馏可把两个确定性教师步骤压成一个学生步骤，重复这一过程降低生成时的函数评价次数¹¹。

代价转移到额外训练及学生对教师的近似中；学生映射若没有相应的可逆性和密度追踪机制，也不会自动继承教师 ODE 的似然公式。无论采用求解器加速还是蒸馏，扩散索引始终是人为噪声尺度。对视频等真实时序数据，可以在整个序列或其潜表示上另加一条扩散轴，但必须把这两个索引分开。

¹¹ T. Salimans, J. Ho, *Progressive Distillation for Fast Sampling of Diffusion Models* In International Conference on Learning Representations, 2022

29.5 模型关系与比较

29.5.1 似然、后验与采样

比较这些模型时，应固定查询对象。完整观测的密度、给定部分观测的条件分布、潜变量后验、无条件样本是四种不同查询。Flow 完整密度可算，并不意味着对任意缺失坐标的积分也可算；VAE 有快速编码器，并不意味着它输出了精确后验；DDPM 能随机抽步训练，也不意味着生成只需一步。

VAE、Flow 和扩散并未用尽换取可计算性的办法。**概率电路** (probabilistic circuit, PC) 把分布写成由简单叶分布、加权和节点及乘积节点构成的计算图。叶节点能精确评价和边缘化；和节点执行混合，乘积节点组合不同变量块。它以结构约束控制计算，而不是要求每个高维变换可逆¹²。

一种足够的归一化设定是：每个叶分布归一化，和节点权重非负且和为

¹² Y. Choi, A. Vergari, G. Van den Broeck, *Probabilistic Circuits: A Unifying Framework for Tractable Probabilistic Models*, Unpublished manuscript, University of California, Los Angeles, 2020, URL: <https://starai.cs.ucla.edu/papers/ProbCirc20.pdf>

1; 和节点各孩子涉及同一组变量, 称为**光滑性** (smoothness), 也称完备性; 乘积节点各孩子涉及互不相交的变量组, 称为**可分解性** (decomposability)。由叶向根归纳, 和保持归一化, 互不相交变量上的乘积也保持归一化。边缘化时可在叶节点上先积分, 再沿相同加法和乘法向上传播, 因为可分解性允许把对不同变量块的积分拆开。设边数为 m 且叶查询为常数成本, 则一次向上传播为 $O(m)$; 条件化分母的边缘概率质量或密度为正时, 条件分布可由两个相应边缘量之比得到。

这类结论是相对于已经给定的电路大小而言的, 某些分布可能需要很大的电路。上述条件也不保证所有 MAP 或边缘 MAP 查询都同样容易, 不能把求和直接换成最大化便宣称解决。对本章的比较而言, 概率电路补充了一个坐标: 让完整密度可算与让大量边缘查询可算, 是不同层次的结构要求。表 29.1 按这些计算对象概括本章的取舍。

机制	完整观测的似然	潜变量与条件查询	典型采样代价与限制
自回归基线	条件分解给出精确似然	一般缺失坐标不一定能高效边缘化	通常按坐标顺序生成; 依赖排序
VAE	通常优化 ELBO, 边缘似然需额外估计	编码器给出近似后验	先抽潜变量再解码; 条件似然决定额外成本
离散层 Flow	逆变换与 Jacobian 可行时精确	完整观测有唯一逆像; 部分观测仍可能需积分	逐层变换; 自回归流有方向性成本
DDPM	路径 ELBO 可估计; 简化损失不是似然值	固定前向路径充当变分分布	多步随机转移; 有限终点与参数化有误差
分数 ODE	散度积分定义 ODE 模型密度	可逆流给出编码, 不是随机路径后验	数值积分; 精度与函数评价次数相关
受约束概率电路	可精确评价归一化密度或质量	合适结构下可精确边缘化与条件查询	结构化采样; 表示规模可能很大

表 29.1 统一查询口径下的比较。“精确”指模型中无需变分或边缘化近似的数学计算关系, 不排除浮点误差; 连续流和分数 ODE 还涉及数值积分及可能的随机迹估计。概率电路一行采用正文给出的光滑、可分解及归一化条件。

即使似然评价完全一致, 生成质量也没有因此被一个数值穷尽。似然比较必须使用相同观测表示、测度和预处理; 样本是否具有任务所需结构、是否覆盖多种模式、采样资源是否可接受, 则需要各自的评价。贯穿例子中三条路线都可表达 $\mathcal{N}(0, 5)$, 已经说明仅由边缘分布不能反推出唯一的计算机制或潜变量解释。复杂数据上, 有限网络容量、推断族与数值预算会把这些机制上的差异转化为实际误差。

29.5.2 生成机制的组合

三种机制的组合应从“哪一个分布被改变”判断。Flow 后验只把 $q_{\phi}(\mathbf{z} | \mathbf{x})$ 变得灵活, 主要针对近似族误差; 若基础后验和新增变换允许保留原分布作为特例, 理论最优下界不会因扩族而降低, 但实际优化不保证达到它。给 VAE 换成 Flow 先验, 则改变了 $p_{\theta}(\mathbf{z})$, 直接作用于生成时如何访问潜空间。两者都出现可逆网络, 却解决不同的问题。

层次 VAE 把复杂性放进多层随机依赖。对于前文的两层例子，若取 $q_\phi(\mathbf{z}_1, \mathbf{z}_2 | \mathbf{x}) = q_\phi(\mathbf{z}_1 | \mathbf{x})q_\phi(\mathbf{z}_2 | \mathbf{z}_1, \mathbf{x})$ ，ELBO 就是

$$\mathbb{E}_{q_\phi} \left[\log \frac{p(\mathbf{z}_2)p_\theta(\mathbf{z}_1 | \mathbf{z}_2)p_\theta(\mathbf{x} | \mathbf{z}_1)}{q_\phi(\mathbf{z}_1 | \mathbf{x})q_\phi(\mathbf{z}_2 | \mathbf{z}_1, \mathbf{x})} \right].$$

它仍是同一个联合与变分路径之比。逐层抽样可以估计该期望，但每层都有自己的后验匹配问题；增加层数不自动消除坍塌。扩散也含多层潜状态，但其尺度、固定前向核及局部目标具有专门设计，不能仅因为“层数多”就与任意层次 VAE 等同。

潜空间扩散（latent diffusion）把多步生成放在观测的潜表示中：先学习编码与解码，再在编码得到的潜变量分布上训练扩散模型，最后把生成的潜变量解码为观测。其主要计算收益来自反复去噪的空间更小；原始潜空间扩散工作在预训练自编码表示上构造这一过程¹³。

若解码器是归一化条件分布 $p_\psi(\mathbf{x} | \mathbf{z})$ ，潜空间生成先验为 $p_\theta^{\text{diff}}(\mathbf{z})$ ，整体模型为

$$p_{\theta, \psi}(\mathbf{x}) = \int p_\psi(\mathbf{x} | \mathbf{z})p_\theta^{\text{diff}}(\mathbf{z}) d\mathbf{z}. \quad (29.36)$$

这又回到了潜变量边缘化：即使潜空间密度可评价，也不能省略观测空间的积分。若解码器只是非可逆确定性网络，或编码阶段主要用感知损失训练，就不能自动宣称得到了同一像素空间上的可计算似然。压缩误差、潜空间分布拟合和解码条件分布的局限，都需要分别考察。这些组合把计算放到了更合适的位置，但没有免除每一层概率定义的责任。

29.5.3 与隐式生成模型的边界

假设只给出 $\mathbf{Z} \sim p_0$ 和生成程序 $\mathbf{X} = G_\theta(\mathbf{Z})$ 。对任意可测集合 B ，它已经规定

$$\mathbb{P}_\theta(\mathbf{X} \in B) = \int \mathbf{1}\{G_\theta(\mathbf{z}) \in B\}p_0(\mathbf{z}) d\mathbf{z}. \quad (29.37)$$

这种通过采样程序间接规定的分布称为**隐式分布**（implicit distribution）。**生成对抗网络**（generative adversarial network, GAN）是常见例子：通常的生成器提供样本，却不提供像式 (29.11) 那样可直接评价的观测密度。本节只比较这一概率语义，不展开其对抗训练过程¹⁴。

困难既可能是计算性的，也可能是测度上的。同维光滑映射即使处处局部可逆，只要全局多对一，密度通常也要累加所有逆像的贡献；普通网络没有保证逆像可枚举。若 $\mathbf{Z}$ 维度小于观测维度，且 G_θ 为通常的局部 Lipschitz 网络，输出还可能集中在低维集合上，不具有相对于整个观测空间 Lebesgue 测度的密度。它仍是合法概率分布，只是不适用本章默认的 d 维密度公式。

Flow 也把噪声推送成观测，所以“由噪声生成”不是 GAN 与 Flow 的

¹³ R. Rombach, A. Blattmann, D. Lorenz, P. Esser, B. Ommer, *High-Resolution Image Synthesis with Latent Diffusion Models* In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2022, pp. 10684–10695

¹⁴ I. J. Goodfellow, J. Pouget-Abadie, M. Mirza, B. Xu, D. Warde-Farley, S. Ozair, A. Courville, Y. Bengio, *Generative Adversarial Networks* In arXiv preprint arXiv:1406.2661, 2014

边界。边界在于是否额外规定可逆性、同维变换、可计算体积因子等条件，使隐含分布具有可评价密度。VAE 与离散扩散的观测密度虽然通常难以直接求值，但它们给出可评价的联合分布和明确的边缘化对象，因而能构造有概率含义的似然下界。能够采样、存在密度、密度可算、能算似然界，是针对不同性质和计算任务的陈述；不能从能够采样直接推出其余几项，也不能用一个下界代替密度本身。

29.6 本章小结

复杂生成模型的共同难题不是单纯增加网络容量，而是在归一化、密度评价、推断和采样之间安排可计算的结构。VAE 允许多个潜变量解释同一观测，以边缘化定义密度，用近似后验和 ELBO 支撑学习；规范化流用同维可逆变换让每个完整观测有唯一逆像，以 Jacobian 追踪体积；扩散把生成放在人工噪声过程上，用可计算的局部去噪问题学习逆转移。这三种机制可以组合，也可以表达相同的观测分布，却具有不同的潜变量含义和查询成本。

比较训练目标时，需要保留被简化的部分。VAE 的重构项由观测似然决定，灵活后验不自动使观测似然精确可算；DDPM 的严格路径 ELBO 包含终点项、逐步加权 KL 和解码项，均匀噪声回归不是其数值替身。连续时间下，逆 SDE 的符号必须与递减时间一起理解，概率流 ODE 的同边缘结论需要真分数和匹配的边界条件；计算 ODE 模型似然还需散度积分，并承担数值与迹估计误差。

模型选择因此应从所需查询出发：需要快速潜变量推断，就考察近似后验及其误差；需要完整观测密度，就考察逆变换或积分成本；需要大量缺失变量查询，还要考察边缘化结构；需要低延迟生成，则应把每次网络评价和顺序依赖算入预算。显式联合分布、可评价密度和方便的采样程序并不是同一件事。明确这些区别，才能把生成样本的直观表现与模型实际支持的概率结论联系起来。



参考文献

- D. Achlioptas, *Database-friendly random projections: Johnson-Lindenstrauss with binary coins* In Journal of Computer and System Sciences, 2003, vol. 66, no. 4, pp. 671–687.
- C. C. Aggarwal, *Recommender Systems*, Springer, 2016.
- R. Agrawal, J. Gehrke, D. Gunopulos, P. Raghavan, *Automatic Subspace Clustering of High Dimensional Data for Data Mining Applications* In Proceedings of the ACM SIGMOD International Conference on Management of Data, 1998, pp. 94–105.
- M. Aharon, M. Elad, A. Bruckstein, *K-SVD: An Algorithm for Designing Overcomplete Dictionaries for Sparse Representation* In IEEE Transactions on Signal Processing, 2006, vol. 54, no. 11, pp. 4311–4322.
- N. Ailon, B. Chazelle, *The Fast Johnson–Lindenstrauss Transform and Approximate Nearest Neighbors* In SIAM Journal on Computing, 2009, vol. 39, no. 1, pp. 302–322.
- J. Ainslie, J. Lee-Thorp, M. de Jong, Y. Zemlyanskiy, F. Lebrón, S. Sanghai, *GQA: Training Generalized Multi-Query Transformer Models from Multi-Head Checkpoints* In arXiv preprint arXiv:2305.13245, 2023.
- M. A. Aizerman, E. M. Braverman, L. I. Rozonoer, *Theoretical Foundations of the Potential Function Method in Pattern Recognition Learning* In Automation and Remote Control, 1964, vol. 25, pp. 821–837.
- A. Albert, J. A. Anderson, *On the Existence of Maximum Likelihood Estimates in Logistic Regression Models* In Biometrika, 1984, vol. 71, no. 1, pp. 1–10.
- Y. Aliyari Ghassabeh, *A Sufficient Condition for the Convergence of the Mean Shift Algorithm with Gaussian Kernel* In Journal of Multivariate Analysis, 2015, vol. 135, pp. 1–10.
- D. Aloise, A. Deshpande, P. Hansen, P. Popat, *NP-Hardness of Euclidean Sum-of-Squares Clustering* In Machine Learning, 2009, vol. 75, no. 2, pp. 245–248.

- U. Alon, E. Yahav, *On the Bottleneck of Graph Neural Networks and Its Practical Implications* In International Conference on Learning Representations, 2021.
- E. Amid, M. K. Warmuth, *TriMap: Large-Scale Dimensionality Reduction Using Triplets*, 2019, arXiv: [1910.00204](https://arxiv.org/abs/1910.00204), URL: <https://arxiv.org/abs/1910.00204>.
- A. Amir, B. Taba, D. Berg, T. Melano, J. McKinstry, C. Di Nolfo, T. Nayak, A. Andreopoulos, G. Garreau, M. Mendoza, J. Kusnitz, M. DeBole, S. Esser, T. Delbruck, M. Flickner, D. Modha, *A Low Power, Fully Event-Based Gesture Recognition System* In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2017, pp. 7243–7252.
- T. W. Anderson, *Classification by Multivariate Analysis* In Psychometrika, 1951, vol. 16, no. 1, pp. 31–50.
- G. Andrew, R. Arora, J. Bilmes, K. Livescu, *Deep Canonical Correlation Analysis* In Proceedings of the 30th International Conference on Machine Learning, 2013, pp. 1247–1255.
- A. N. Angelopoulos, S. Bates, *A Gentle Introduction to Conformal Prediction and Distribution-Free Uncertainty Quantification* In arXiv preprint arXiv:2107.07511, 2022.
- M. Ankerst, M. M. Breunig, H.-P. Kriegel, J. Sander, *OPTICS: Ordering Points to Identify the Clustering Structure* In Proceedings of the ACM SIGMOD International Conference on Management of Data, 1999, pp. 49–60.
- E. Arazo, D. Ortego, P. Albert, N. E. O'Connor, K. McGuinness, *Pseudo-Labeling and Confirmation Bias in Deep Semi-Supervised Learning* In 2020 International Joint Conference on Neural Networks, 2020, pp. 1–8.
- M. Arjovsky, A. Shah, Y. Bengio, *Unitary Evolution Recurrent Neural Networks* In Proceedings of the 33rd International Conference on Machine Learning, 2016, pp. 1120–1128.
- N. Aronszajn, *Theory of Reproducing Kernels* In Transactions of the American Mathematical Society, 1950, vol. 68, no. 3, pp. 337–404.
- D. Arthur, S. Vassilvitskii, *k-means++: The Advantages of Careful Seeding* In Proceedings of the Eighteenth Annual ACM-SIAM Symposium on Discrete Algorithms, 2007, pp. 1027–1035.
- F. A. C. Azevedo, L. R. B. Carvalho, L. T. Grinberg, J. M. Farfel, R. E. L. Ferretti, R. E. P. Leite, W. Jacob Filho, R. Lent, S. Herculano-Houzel, *Equal Numbers of Neuronal and Nonneuronal Cells Make the Human Brain an Isometrically Scaled-Up Primate Brain* In The Journal of Comparative Neurology, 2009, vol. 513, no. 5, pp. 532–541.

- J. L. Ba, J. R. Kiros, G. E. Hinton, *Layer Normalization* In arXiv preprint arXiv:1607.06450, 2016.
- T. Bachlechner, B. P. Majumder, H. H. Mao, G. W. Cottrell, J. McAuley, *ReZero Is All You Need: Fast Convergence at Large Depth* In arXiv preprint arXiv:2003.04887, 2020.
- D. Bahdanau, K. Cho, Y. Bengio, *Neural Machine Translation by Jointly Learning to Align and Translate* In International Conference on Learning Representations, 2015.
- M. Bar, K. S. Kassam, A. S. Ghuman, J. Boshyan, A. M. Schmid, A. M. Schmidt, A. M. Dale, M. S. Hämmäläinen, K. Marinkovic, D. L. Schacter, B. R. Rosen, E. Halgren, *Top-down Facilitation of Visual Recognition* In Proceedings of the National Academy of Sciences, 2006, vol. 103, no. 2, pp. 449–454.
- P. L. Bartlett, S. Mendelson, *Rademacher and Gaussian Complexities: Risk Bounds and Structural Results* In Journal of Machine Learning Research, 2002, vol. 3, pp. 463–482.
- S. Basu, A. Banerjee, R. J. Mooney, *Semi-Supervised Clustering by Seeding* In Proceedings of the Nineteenth International Conference on Machine Learning, 2002, pp. 27–34.
- A. G. Baydin, B. A. Pearlmutter, A. A. Radul, J. M. Siskind, *Automatic Differentiation in Machine Learning: A Survey* In Journal of Machine Learning Research, 2018, vol. 18, no. 153, pp. 1–43.
- A. Beck, M. Teboulle, *A Fast Iterative Shrinkage-Thresholding Algorithm for Linear Inverse Problems* In SIAM Journal on Imaging Sciences, 2009, vol. 2, no. 1, pp. 183–202.
- P. N. Belhumeur, J. P. Hespanha, D. J. Kriegman, *Eigenfaces vs. Fisherfaces: Recognition Using Class Specific Linear Projection* In IEEE Transactions on Pattern Analysis and Machine Intelligence, 1997, vol. 19, no. 7, pp. 711–720.
- M. Belkin, P. Niyogi, *Convergence of Laplacian Eigenmaps* In Advances in Neural Information Processing Systems, 2006, pp. 129–136.
- M. Belkin, P. Niyogi, *Laplacian Eigenmaps for Dimensionality Reduction and Data Representation* In Neural Computation, 2003, vol. 15, no. 6, pp. 1373–1396.
- M. Belkin, P. Niyogi, V. Sindhwani, *Manifold Regularization: A Geometric Framework for Learning from Labeled and Unlabeled Examples* In Journal of Machine Learning Research, 2006, vol. 7, pp. 2399–2434.

- A. J. Bell, T. J. Sejnowski, *An Information-Maximization Approach to Blind Separation and Blind Deconvolution* In Neural Computation, 1995, vol. 7, no. 6, pp. 1129–1159.
- S. Ben-David, U. von Luxburg, D. Pál, *A Sober Look at Clustering Stability* In Learning Theory, 2006, pp. 5–19.
- Y. Bengio, J.-F. Paiement, P. Vincent, O. Delalleau, N. Le Roux, M. Ouimet, *Out-of-Sample Extensions for LLE, Isomap, MDS, Eigenmaps, and Spectral Clustering* In Advances in Neural Information Processing Systems, 2003, pp. 177–184.
- Y. Bengio, P. Simard, P. Frasconi, *Learning Long-Term Dependencies with Gradient Descent Is Difficult* In IEEE Transactions on Neural Networks, 1994, vol. 5, no. 2, pp. 157–166.
- J. C. Bezdek, *Pattern Recognition with Fuzzy Objective Function Algorithms*, Plenum Press, 1981, 1st ed.
- G.-q. Bi, M.-m. Poo, *Synaptic Modifications in Cultured Hippocampal Neurons: Dependence on Spike Timing, Synaptic Strength, and Postsynaptic Cell Type* In The Journal of Neuroscience, 1998, vol. 18, no. 24, pp. 10464–10472.
- M. Bilenko, S. Basu, R. J. Mooney, *Integrating Constraints and Metric Learning in Semi-Supervised Clustering* In Proceedings of the Twenty-First International Conference on Machine Learning, 2004, pp. 81–88.
- G. Birkhoff, *Tres observaciones sobre el álgebra lineal* In Universidad Nacional de Tucumán. Revista. Serie A, 1946, vol. 5, pp. 147–151.
- C. M. Bishop, *Bayesian PCA* In Advances in Neural Information Processing Systems, 1999, pp. 382–388.
- C. M. Bishop, *Pattern Recognition and Machine Learning*, Springer, 2006, 1st ed.
- C. M. Bishop, H. Bishop, *Deep Learning: Foundations and Concepts*, Springer, 2024.
- G. Blanchard, O. Bousquet, L. Zwald, *Statistical Properties of Kernel Principal Component Analysis* In Machine Learning, 2007, vol. 66, no. 2–3, pp. 259–294.
- D. M. Blei, A. Y. Ng, M. I. Jordan, *Latent Dirichlet Allocation* In Journal of Machine Learning Research, 2003, vol. 3, pp. 993–1022.
- V. D. Blondel, J.-L. Guillaume, R. Lambiotte, E. Lefebvre, *Fast Unfolding of Communities in Large Networks* In Journal of Statistical Mechanics: Theory and Experiment, 2008, vol. 2008, no. 10, P10008.

- A. Blum, T. Mitchell, *Combining Labeled and Unlabeled Data with Co-Training* In Proceedings of the Eleventh Annual Conference on Computational Learning Theory, 1998, pp. 92–100.
- S. M. Bohte, J. N. Kok, H. la Poutre, *Error-backpropagation in Temporally Encoded Networks of Spiking Neurons* In Neurocomputing, 2002, vol. 48, no. 1–4, pp. 17–37.
- B. E. Boser, I. M. Guyon, V. N. Vapnik, *A Training Algorithm for Optimal Margin Classifiers* In Proceedings of the Fifth Annual Workshop on Computational Learning Theory, 1992, pp. 144–152.
- L. Bottou, F. E. Curtis, J. Nocedal, *Optimization Methods for Large-Scale Machine Learning* In SIAM Review, 2018, vol. 60, no. 2, pp. 223–311.
- Y. Boykov, O. Veksler, R. Zabih, *Fast Approximate Energy Minimization via Graph Cuts* In IEEE Transactions on Pattern Analysis and Machine Intelligence, 2001, vol. 23, no. 11, pp. 1222–1239.
- P. S. Bradley, K. P. Bennett, A. Demiriz, *Constrained K-Means Clustering*, tech. rep. MSR-TR-2000-65, Microsoft Research, 2000.
- L. Breiman, *Bagging Predictors* In Machine Learning, 1996, vol. 24, no. 2, pp. 123–140.
- L. Breiman, *Random Forests* In Machine Learning, 2001, vol. 45, no. 1, pp. 5–32.
- L. Breiman, *Stacked Regressions* In Machine Learning, 1996, vol. 24, no. 1, pp. 49–64.
- L. Breiman, J. H. Friedman, R. A. Olshen, C. J. Stone, *Classification and Regression Trees*, Wadsworth International Group, 1984, 1st ed.
- A. Brock, S. De, S. L. Smith, K. Simonyan, *High-Performance Large-Scale Image Recognition Without Normalization* In Proceedings of the 38th International Conference on Machine Learning, 2021.
- T. B. Brown, B. Mann, N. Ryder, M. Subbiah, J. Kaplan, P. Dhariwal, A. Neelakantan, P. Shyam, G. Sastry, A. Askell, S. Agarwal, A. Herbert-Voss, G. Krueger, T. Henighan, R. Child, A. Ramesh, D. M. Ziegler, J. Wu, C. Winter, C. Hesse, M. Chen, E. Sigler, M. Litwin, S. Gray, B. Chess, J. Clark, C. Berner, S. McCandlish, A. Radford, I. Sutskever, D. Amodei, *Language Models Are Few-Shot Learners* In Advances in Neural Information Processing Systems 33, 2020, pp. 1877–1901.
- J. Bruna, W. Zaremba, A. Szlam, Y. LeCun, *Spectral Networks and Locally Connected Networks on Graphs* In International Conference on Learning Representations, 2014.

- C. Bucila, R. Caruana, A. Niculescu-Mizil, *Model Compression* In Proceedings of the 12th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 2006, pp. 535–541.
- T. Cai, S. Luo, K. Xu, D. He, T.-Y. Liu, L. Wang, *GraphNorm: A Principled Approach to Accelerating Graph Neural Network Training* In Proceedings of the 38th International Conference on Machine Learning, 2021.
- R. J. G. B. Campello, D. Moulavi, J. Sander, *Density-Based Clustering Based on Hierarchical Density Estimates* In Advances in Knowledge Discovery and Data Mining, 2013, pp. 160–172.
- E. J. Candès, X. Li, Y. Ma, J. Wright, *Robust principal component analysis?* In Journal of the ACM, 2011, vol. 58, no. 3, pp. 1–37.
- R. Caruana, A. Niculescu-Mizil, G. Crew, A. Ksikes, *Ensemble Selection from Libraries of Models* In Proceedings of the Twenty-First International Conference on Machine Learning, 2004, pp. 18.
- N. Cesa-Bianchi, A. Conconi, C. Gentile, *On the Generalization Ability of On-Line Learning Algorithms* In IEEE Transactions on Information Theory, 2004, vol. 50, no. 9, pp. 2050–2057.
- V. Chandrasekaran, P. A. Parrilo, A. S. Willsky, *Latent Variable Graphical Model Selection via Convex Optimization* In The Annals of Statistics, 2012, vol. 40, no. 4, pp. 1935–1967.
- C.-C. Chang, C.-J. Lin, *LIBSVM: A Library for Support Vector Machines* In ACM Transactions on Intelligent Systems and Technology, 2011, vol. 2, no. 3, pp. 27:1–27:27.
- T. Chen, C. Guestrin, *XGBoost: A Scalable Tree Boosting System* In Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 2016, pp. 785–794.
- X. Chen, C. Liang, D. Huang, E. Real, K. Wang, Y. Liu, H. Pham, X. Dong, T. Luong, C.-J. Hsieh, Y. Lu, Q. V. Le, *Symbolic Discovery of Optimization Algorithms* In Advances in Neural Information Processing Systems 36, 2023.
- J. Cheng, L. Dong, M. Lapata, *Long Short-Term Memory-Networks for Machine Reading* In Proceedings of the 2016 Conference on Empirical Methods in Natural Language Processing, 2016, pp. 551–561.
- Y. Cheng, *Mean Shift, Mode Seeking, and Clustering* In IEEE Transactions on Pattern Analysis and Machine Intelligence, 1995, vol. 17, no. 8, pp. 790–799.
- D. M. Chickering, *Optimal Structure Identification with Greedy Search* In Journal of Machine Learning Research, 2002, vol. 3, pp. 507–554.

- R. Child, S. Gray, A. Radford, I. Sutskever, *Generating Long Sequences with Sparse Transformers* In arXiv preprint arXiv:1904.10509, 2019.
- V. Chiley, I. Sharapov, A. Kosson, U. Köster, R. Reece, S. Samaniego de la Fuente, V. Subbiah, M. James, *Online Normalization for Training Neural Networks* In Advances in Neural Information Processing Systems 32, 2019.
- H. A. Chipman, E. I. George, R. E. McCulloch, *BART: Bayesian Additive Regression Trees* In The Annals of Applied Statistics, 2010, vol. 4, no. 1, pp. 266–298.
- K. Cho, B. van Merriënboer, C. Gulcehre, D. Bahdanau, F. Bougares, H. Schwenk, Y. Bengio, *Learning Phrase Representations using RNN Encoder–Decoder for Statistical Machine Translation* In Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing, 2014, pp. 1724–1734.
- D. Choi, C. J. Shallue, Z. Nado, J. Lee, C. J. Maddison, G. E. Dahl, *On Empirical Comparisons of Optimizers for Deep Learning* In arXiv preprint arXiv:1910.05446, 2020.
- Y. Choi, A. Vergari, G. Van den Broeck, *Probabilistic Circuits: A Unifying Framework for Tractable Probabilistic Models*, Unpublished manuscript, University of California, Los Angeles, 2020, URL: <https://starai.cs.ucla.edu/papers/ProbCirc20.pdf>.
- N. Chopin, *Central Limit Theorem for Sequential Monte Carlo Methods and Its Application to Bayesian Inference* In The Annals of Statistics, 2004, vol. 32, no. 6, pp. 2385–2411.
- C. K. Chow, C. N. Liu, *Approximating Discrete Probability Distributions with Dependence Trees* In IEEE Transactions on Information Theory, 1968, vol. 14, no. 3, pp. 462–467.
- F. R. K. Chung, *Spectral Graph Theory*, American Mathematical Society, 1997, 1st ed.
- D. C. Cireşan, U. Meier, J. Masci, L. M. Gambardella, J. Schmidhuber, *Flexible, High Performance Convolutional Neural Networks for Image Classification* In Proceedings of the Twenty-Second International Joint Conference on Artificial Intelligence, 2011, pp. 1237–1242.
- P. Clark, R. Boswell, *Rule Induction with CN2: Some Recent Improvements* In Machine Learning—EWSL-91, 1991, pp. 151–163.
- P. Clark, T. Niblett, *The CN2 Induction Algorithm* In Machine Learning, 1989, vol. 3, no. 4, pp. 261–283.

- W. S. Cleveland, *Robust Locally Weighted Regression and Smoothing Scatterplots* In Journal of the American Statistical Association, 1979, vol. 74, no. 368, pp. 829–836.
- D.-A. Clevert, T. Unterthiner, S. Hochreiter, *Fast and Accurate Deep Network Learning by Exponential Linear Units (ELUs)* In arXiv preprint arXiv:1511.07289, 2016.
- W. W. Cohen, *Fast Effective Rule Induction* In Machine Learning Proceedings 1995, 1995, pp. 115–123.
- R. R. Coifman, S. Lafon, *Diffusion Maps* In Applied and Computational Harmonic Analysis, 2006, vol. 21, no. 1, pp. 5–30.
- R. R. Coifman, M. Maggioni, *Diffusion Wavelets* In Applied and Computational Harmonic Analysis, 2006, vol. 21, no. 1, pp. 53–94.
- M. Collins, *Discriminative Training Methods for Hidden Markov Models: Theory and Experiments with Perceptron Algorithms* In Proceedings of the 2002 Conference on Empirical Methods in Natural Language Processing, 2002, pp. 1–8.
- M. Collins, S. Dasgupta, R. E. Schapire, *A Generalization of Principal Components Analysis to the Exponential Family* In Advances in Neural Information Processing Systems, 2001, pp. 617–624.
- D. Comaniciu, P. Meer, *Mean Shift: A Robust Approach toward Feature Space Analysis* In IEEE Transactions on Pattern Analysis and Machine Intelligence, 2002, vol. 24, no. 5, pp. 603–619.
- P. Comon, *Independent component analysis, A new concept?* In Signal Processing, 1994, vol. 36, no. 3, pp. 287–314.
- J. W. Cooley, J. W. Tukey, *An Algorithm for the Machine Calculation of Complex Fourier Series* In Mathematics of Computation, 1965, vol. 19, no. 90, pp. 297–301.
- C. Cortes, V. Vapnik, *Support-Vector Networks* In Machine Learning, 1995, vol. 20, no. 3, pp. 273–297.
- T. M. Cover, P. E. Hart, *Nearest Neighbor Pattern Classification* In IEEE Transactions on Information Theory, 1967, vol. 13, no. 1, pp. 21–27.
- D. R. Cox, *The Regression Analysis of Binary Sequences* In Journal of the Royal Statistical Society: Series B (Methodological), 1958, vol. 20, no. 2, pp. 215–232.
- F. G. Cozman, I. Cohen, *Unlabeled Data Can Degrade Classification Performance of Generative Classifiers* In Proceedings of the Fifteenth International Florida Artificial Intelligence Research Society Conference, 2002, pp. 327–331.

- J. S. Cramer, *The Origins of Logistic Regression*, Discussion Paper 2002-119/4, Tinbergen Institute, 2002.
- K. Crammer, O. Dekel, J. Keshet, S. Shalev-Shwartz, Y. Singer, *Online Passive-Aggressive Algorithms* In Journal of Machine Learning Research, 2006, vol. 7, pp. 551–585.
- K. Crammer, Y. Singer, *On the Algorithmic Implementation of Multiclass Kernel-based Vector Machines* In Journal of Machine Learning Research, 2001, vol. 2, pp. 265–292.
- C. Cremer, X. Li, D. Duvenaud, *Inference Suboptimality in Variational Autoencoders* In Proceedings of the 35th International Conference on Machine Learning, 2018, pp. 1078–1086.
- S. Damrich, F. A. Hamprecht, *On UMAP’s True Loss Function* In Advances in Neural Information Processing Systems, 2021, pp. 5798–5809.
- T. Dao, D. Y. Fu, S. Ermon, A. Rudra, C. Ré, *FlashAttention: Fast and Memory-Efficient Exact Attention with IO-Awareness* In arXiv preprint arXiv:2205.14135, 2022.
- Y. N. Dauphin, R. Pascanu, C. Gulcehre, K. Cho, S. Ganguli, Y. Bengio, *Identifying and Attacking the Saddle Point Problem in High-Dimensional Non-Convex Optimization* In Advances in Neural Information Processing Systems 27, 2014, pp. 2933–2941.
- R. Dechter, *Bucket Elimination: A Unifying Framework for Reasoning* In Artificial Intelligence, 1999, vol. 113, pp. 41–85.
- M. Defferrard, X. Bresson, P. Vandergheynst, *Convolutional Neural Networks on Graphs with Fast Localized Spectral Filtering* In Advances in Neural Information Processing Systems, 2016.
- M. P. Deisenroth, A. A. Faisal, C. S. Ong, *Mathematics for Machine Learning*, Cambridge University Press, 2020.
- A. P. Dempster, N. M. Laird, D. B. Rubin, *Maximum Likelihood from Incomplete Data via the EM Algorithm* In Journal of the Royal Statistical Society: Series B (Methodological), 1977, vol. 39, no. 1, pp. 1–22.
- A. P. Dempster, N. M. Laird, D. B. Rubin, *Maximum Likelihood from Incomplete Data via the EM Algorithm* In Journal of the Royal Statistical Society: Series B (Methodological), 1977, vol. 39, no. 1, pp. 1–38.
- J. Devlin, M.-W. Chang, K. Lee, K. Toutanova, *BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding* In Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, 2019, pp. 4171–4186.

- I. S. Dhillon, Y. Guan, B. Kulis, *Kernel k-Means, Spectral Clustering and Normalized Cuts* In Proceedings of the Tenth ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 2004, pp. 551–556.
- T. G. Dietterich, G. Bakiri, *Solving Multiclass Learning Problems via Error-Correcting Output Codes* In Journal of Artificial Intelligence Research, 1995, vol. 2, pp. 263–286.
- C. Ding, T. Li, W. Peng, *On the Equivalence between Non-negative Matrix Factorization and Probabilistic Latent Semantic Indexing* In Computational Statistics & Data Analysis, 2008, vol. 52, no. 8, pp. 3913–3927.
- L. Dinh, R. Pascanu, S. Bengio, Y. Bengio, *Sharp Minima Can Generalize for Deep Nets* In Proceedings of the 34th International Conference on Machine Learning, 2017, pp. 1019–1028.
- L. Dinh, J. Sohl-Dickstein, S. Bengio, *Density Estimation Using Real NVP* In International Conference on Learning Representations, 2017.
- P. Domingos, M. Pazzani, *On the Optimality of the Simple Bayesian Classifier under Zero-One Loss* In Machine Learning, 1997, vol. 29, no. 2-3, pp. 103–130.
- W. E. Donath, A. J. Hoffman, *Lower Bounds for the Partitioning of Graphs* In IBM Journal of Research and Development, 1973, vol. 17, no. 5, pp. 420–425.
- D. L. Donoho, C. Grimes, *Hessian Eigenmaps: Locally Linear Embedding Techniques for High-Dimensional Data* In Proceedings of the National Academy of Sciences, 2003, vol. 100, no. 10, pp. 5591–5596.
- A. Dosovitskiy, L. Beyer, A. Kolesnikov, D. Weissenborn, X. Zhai, T. Unterthiner, M. Dehghani, M. Minderer, G. Heigold, S. Gelly, J. Uszkoreit, N. Houlsby, *An Image Is Worth 16x16 Words: Transformers for Image Recognition at Scale* In arXiv preprint arXiv:2010.11929, 2020.
- R. Douc, O. Cappé, E. Moulines, *Comparison of Resampling Schemes for Particle Filtering* In 4th International Symposium on Image and Signal Processing and Analysis, 2005, pp. 64–69.
- A. Doucet, N. de Freitas, K. Murphy, S. Russell, *Rao-Blackwellised Particle Filtering for Dynamic Bayesian Networks* In Proceedings of the Sixteenth Conference on Uncertainty in Artificial Intelligence, 2000, pp. 176–183.
- Y. Du, I. Mordatch, *Implicit Generation and Modeling with Energy Based Models* In Advances in Neural Information Processing Systems, 2019.
- J. Duchi, E. Hazan, Y. Singer, *Adaptive Subgradient Methods for Online Learning and Stochastic Optimization* In Journal of Machine Learning Research, 2011, vol. 12, no. 61, pp. 2121–2159.

- S. A. Dudani, *The Distance-Weighted k -Nearest-Neighbor Rule* In IEEE Transactions on Systems, Man, and Cybernetics, 1976, vol. SMC-6, no. 4, pp. 325–327.
- M. Dukhan, *The Indirect Convolution Algorithm* In arXiv preprint arXiv:1907.02129, 2019.
- V. Dumoulin, F. Visin, *A Guide to Convolution Arithmetic for Deep Learning* In arXiv preprint arXiv:1603.07285, 2016.
- C. Eckart, G. Young, *The Approximation of One Matrix by Another of Lower Rank* In Psychometrika, 1936, vol. 1, no. 3, pp. 211–218.
- S. Elfving, E. Uchibe, K. Doya, *Sigmoid-Weighted Linear Units for Neural Network Function Approximation in Reinforcement Learning* In Neural Networks, 2018, vol. 107, pp. 3–11.
- J. L. Elman, *Finding Structure in Time* In Cognitive Science, 1990, vol. 14, no. 2, pp. 179–211.
- G. F. Elsayed, S. Shankar, B. Cheung, N. Papernot, A. Kurakin, I. Goodfellow, J. Sohl-Dickstein, *Adversarial Examples that Fool Both Computer Vision and Time-Limited Humans* In Advances in Neural Information Processing Systems 31, 2018.
- N. Erickson, L. Purucker, A. Tschalzev, D. Holzmüller, P. Mutalik Desai, D. Salinas, F. Hutter, *TabArena: A Living Benchmark for Machine Learning on Tabular Data* In Advances in Neural Information Processing Systems, 2026, vol. 38.
- M. Ester, H.-P. Kriegel, J. Sander, X. Xu, *A Density-Based Algorithm for Discovering Clusters in Large Spatial Databases with Noise* In Proceedings of the Second International Conference on Knowledge Discovery and Data Mining, 1996, pp. 226–231.
- J. Fan, I. Gijbels, *Local Polynomial Modelling and Its Applications*, Chapman & Hall, 1996.
- R.-E. Fan, K.-W. Chang, C.-J. Hsieh, X.-R. Wang, C.-J. Lin, *LIBLINEAR: A Library for Large Linear Classification* In Journal of Machine Learning Research, 2008, vol. 9, pp. 1871–1874.
- R.-E. Fan, P.-H. Chen, C.-J. Lin, *Working Set Selection Using Second Order Information for Training Support Vector Machines* In Journal of Machine Learning Research, 2005, vol. 6, pp. 1889–1918.
- W. Fang, Z. Yu, Y. Chen, T. Huang, T. Masquelier, Y. Tian, *Deep Residual Learning in Spiking Neural Networks* In Advances in Neural Information Processing Systems 34, 2021, pp. 21056–21069.

- Y. Feng, H. You, Z. Zhang, R. Ji, Y. Gao, *Hypergraph Neural Networks* In Proceedings of the AAAI Conference on Artificial Intelligence, 2019, pp. 3558–3565.
- S. Fernandez, E. Pavez, A. Ortega, *L2G-NET: Local to Global Spectral Graph Neural Networks via Cauchy Factorizations* In Proceedings of the 43rd International Conference on Machine Learning, 2026, pp. 30770–30798.
- C. Finn, P. Abbeel, S. Levine, *Model-Agnostic Meta-Learning for Fast Adaptation of Deep Networks* In Proceedings of the 34th International Conference on Machine Learning, 2017, pp. 1126–1135.
- R. A. Fisher, *The Use of Multiple Measurements in Taxonomic Problems* In Annals of Eugenics, 1936, vol. 7, no. 2, pp. 179–188.
- P. Foret, A. Kleiner, H. Mobahi, B. Neyshabur, *Sharpness-Aware Minimization for Efficiently Improving Generalization* In International Conference on Learning Representations, 2021.
- Y. Freund, R. E. Schapire, *A Decision-Theoretic Generalization of On-Line Learning and an Application to Boosting* In Journal of Computer and System Sciences, 1997, vol. 55, no. 1, pp. 119–139.
- Y. Freund, R. E. Schapire, *Large Margin Classification Using the Perceptron Algorithm* In Machine Learning, 1999, vol. 37, no. 3, pp. 277–296.
- B. J. Frey, D. Dueck, *Clustering by Passing Messages between Data Points* In Science, 2007, vol. 315, no. 5814, pp. 972–976.
- J. Friedman, T. Hastie, R. Tibshirani, *Additive Logistic Regression: A Statistical View of Boosting* In The Annals of Statistics, 2000, vol. 28, no. 2, pp. 337–407.
- J. Friedman, T. Hastie, R. Tibshirani, *Sparse Inverse Covariance Estimation with the Graphical Lasso* In Biostatistics, 2008, vol. 9, no. 3, pp. 432–441.
- J. H. Friedman, *Greedy Function Approximation: A Gradient Boosting Machine* In The Annals of Statistics, 2001, vol. 29, no. 5, pp. 1189–1232.
- J. H. Friedman, *Multivariate Adaptive Regression Splines* In The Annals of Statistics, 1991, vol. 19, no. 1, pp. 1–67.
- J. H. Friedman, *Regularized Discriminant Analysis* In Journal of the American Statistical Association, 1989, vol. 84, no. 405, pp. 165–175.
- J. H. Friedman, *Stochastic Gradient Boosting* In Computational Statistics & Data Analysis, 2002, vol. 38, no. 4, pp. 367–378.
- N. Friedman, *The Bayesian Structural EM Algorithm* In Proceedings of the Fourteenth Conference on Uncertainty in Artificial Intelligence, 1998, pp. 129–138.
- N. Friedman, D. Geiger, M. Goldszmidt, *Bayesian Network Classifiers* In Machine Learning, 1997, vol. 29, no. 2-3, pp. 131–163.

- K. Fukunaga, L. D. Hostetler, *The Estimation of the Gradient of a Density Function, with Applications in Pattern Recognition* In IEEE Transactions on Information Theory, 1975, vol. 21, no. 1, pp. 32–40.
- K. Fukushima, *Neocognitron: A Self-Organizing Neural Network Model for a Mechanism of Pattern Recognition Unaffected by Shift in Position* In Biological Cybernetics, 1980, vol. 36, no. 4, pp. 193–202.
- J. Fürnkranz, G. Widmer, *Incremental Reduced Error Pruning* In Machine Learning Proceedings 1994, 1994, pp. 70–77.
- S. I. Gallant, *Perceptron-Based Learning Algorithms* In IEEE Transactions on Neural Networks, 1990, vol. 1, no. 2, pp. 179–191.
- C. Gallicchio, A. Micheli, L. Pedrelli, *Design of Deep Echo State Networks* In Neural Networks, 2018, vol. 108, pp. 33–47.
- F. Galton, *Regression Towards Mediocrity in Hereditary Stature* In The Journal of the Anthropological Institute of Great Britain and Ireland, 1886, vol. 15, pp. 246–263.
- C. F. Gauss, *Theoria motus corporum coelestium in sectionibus conicis solem ambientium*, Perthes et Besser, 1809.
- M. Gavish, D. L. Donoho, *The Optimal Hard Threshold for Singular Values Is $4/\sqrt{3}$* In IEEE Transactions on Information Theory, 2014, vol. 60, no. 8, pp. 5040–5053.
- M. Germain, K. Gregor, I. Murray, H. Larochelle, *MADE: Masked Autoencoder for Distribution Estimation* In Proceedings of the 32nd International Conference on Machine Learning, 2015, pp. 881–889.
- A. Géron, *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow*, O'Reilly Media, 2022, 3rd ed.
- F. A. Gers, J. Schmidhuber, F. Cummins, *Learning to Forget: Continual Prediction with LSTM* In Neural Computation, 2000, vol. 12, no. 10, pp. 2451–2471.
- W. Gerstner, W. M. Kistler, R. Naud, L. Paninski, *Neuronal Dynamics: From Single Neurons to Networks and Models of Cognition*, Cambridge University Press, 2014, 1st ed.
- W. Gerstner, M. Lehmann, V. Liakoni, D. Corneil, J. Brea, *Eligibility Traces and Plasticity on Behavioral Time Scales: Experimental Support of Neo-Hebbian Three-Factor Learning Rules* In Frontiers in Neural Circuits, 2018, vol. 12, 53.
- P. Geurts, D. Ernst, L. Wehenkel, *Extremely Randomized Trees* In Machine Learning, 2006, vol. 63, no. 1, pp. 3–42.

- Z. Ghahramani, G. E. Hinton, *Parameter Estimation for Linear Dynamical Systems*, Technical Report CRG-TR-96-2, Department of Computer Science, University of Toronto, Feb. 22, 1996.
- Z. Ghahramani, M. I. Jordan, *Factorial Hidden Markov Models* In Machine Learning, 1997, vol. 29, pp. 245–273.
- G. Ghiasi, T.-Y. Lin, Q. V. Le, *DropBlock: A Regularization Method for Convolutional Networks* In Advances in Neural Information Processing Systems 31, 2018, pp. 10727–10737.
- R. D. Gill, *The Hammersley–Clifford Theorem*, Mathematical Institute, University of Leiden, Oct. 4, 2011, URL: <https://pub.math.leidenuniv.nl/~gillrd/teaching/graphical/hammersley-clifford.pdf> (visited on 10/03/2026).
- J. Gilmer, S. S. Schoenholz, P. F. Riley, O. Vinyals, G. E. Dahl, *Neural Message Passing for Quantum Chemistry* In Proceedings of the 34th International Conference on Machine Learning, 2017, pp. 1263–1272.
- M. Girolami, *Mercer Kernel-Based Clustering in Feature Space* In IEEE Transactions on Neural Networks, 2002, vol. 13, no. 3, pp. 780–784.
- X. Glorot, Y. Bengio, *Understanding the Difficulty of Training Deep Feedforward Neural Networks* In Proceedings of the Thirteenth International Conference on Artificial Intelligence and Statistics, 2010, pp. 249–256.
- X. Glorot, A. Bordes, Y. Bengio, *Deep Sparse Rectifier Neural Networks* In Proceedings of the Fourteenth International Conference on Artificial Intelligence and Statistics, 2011, pp. 315–323.
- T. Gneiting, A. E. Raftery, *Strictly Proper Scoring Rules, Prediction, and Estimation* In Journal of the American Statistical Association, 2007, vol. 102, no. 477, pp. 359–378.
- J. Goldberger, G. E. Hinton, S. T. Roweis, R. Salakhutdinov, *Neighbourhood Components Analysis* In Advances in Neural Information Processing Systems 17, 2004, pp. 513–520.
- M. A. Goodale, A. D. Milner, *Separate Visual Pathways for Perception and Action* In Trends in Neurosciences, 1992, vol. 15, no. 1, pp. 20–25.
- I. Goodfellow, Y. Bengio, A. Courville, *Deep Learning*, MIT Press, 2016.
- I. Goodfellow, D. Warde-Farley, M. Mirza, A. Courville, Y. Bengio, *Maxout Networks* In Proceedings of the 30th International Conference on Machine Learning, 2013, pp. 1319–1327.
- I. J. Goodfellow, J. Pouget-Abadie, M. Mirza, B. Xu, D. Warde-Farley, S. Ozair, A. Courville, Y. Bengio, *Generative Adversarial Networks* In arXiv preprint arXiv:1406.2661, 2014.

- M. Gori, G. Monfardini, F. Scarselli, *A New Model for Learning in Graph Domains* In Proceedings of the IEEE International Joint Conference on Neural Networks, 2005.
- J. C. Gower, *A General Coefficient of Similarity and Some of Its Properties* In Biometrics, 1971, vol. 27, no. 4, pp. 857–871.
- P. Graham, *A Plan for Spam*, Aug. 2002, URL: <https://paulgraham.com/spam.html>.
- Y. Grandvalet, Y. Bengio, *Semi-supervised Learning by Entropy Minimization* In Advances in Neural Information Processing Systems, 2004, pp. 529–536.
- W. Grathwohl, R. T. Q. Chen, J. Bettencourt, I. Sutskever, D. Duvenaud, *FFJORD: Free-form Continuous Dynamics for Scalable Reversible Generative Models* In arXiv preprint arXiv:1810.01367, 2018.
- A. Graves, S. Fernández, J. Schmidhuber, *Multi-Dimensional Recurrent Neural Networks* In arXiv preprint arXiv:0705.2011, 2007.
- K. Greff, R. K. Srivastava, J. Koutník, B. R. Steunebrink, J. Schmidhuber, *LSTM: A Search Space Odyssey* In IEEE Transactions on Neural Networks and Learning Systems, 2017, vol. 28, no. 10, pp. 2222–2232.
- A. Gu, T. Dao, *Mamba: Linear-Time Sequence Modeling with Selective State Spaces* In arXiv preprint arXiv:2312.00752, 2023.
- A. Gu, T. Dao, S. Ermon, A. Rudra, C. Ré, *HiPPO: Recurrent Memory with Optimal Polynomial Projections* In Advances in Neural Information Processing Systems 33, 2020, pp. 1474–1487.
- A. Gu, K. Goel, C. Ré, *Efficiently Modeling Long Sequences with Structured State Spaces* In International Conference on Learning Representations, 2022.
- S. Guha, R. Rastogi, K. Shim, *CURE: An Efficient Clustering Algorithm for Large Databases* In Proceedings of the ACM SIGMOD International Conference on Management of Data, 1998, pp. 73–84.
- S. Guha, R. Rastogi, K. Shim, *ROCK: A Robust Clustering Algorithm for Categorical Attributes* In Proceedings of the 15th International Conference on Data Engineering, 1999, pp. 512–521.
- C. Guo, G. Pleiss, Y. Sun, K. Q. Weinberger, *On Calibration of Modern Neural Networks* In Proceedings of the 34th International Conference on Machine Learning, 2017, pp. 1321–1330.
- V. Gupta, T. Koren, Y. Singer, *Shampoo: Preconditioned Stochastic Tensor Optimization* In Proceedings of the 35th International Conference on Machine Learning, 2018, pp. 1842–1850.

- M. U. Gutmann, A. Hyvärinen, *Noise-Contrastive Estimation of Unnormalized Statistical Models, with Applications to Natural Image Statistics* In Journal of Machine Learning Research, 2012, vol. 13, no. 11, pp. 307–361.
- R. Haeb-Umbach, H. Ney, *Linear Discriminant Analysis for Improved Large Vocabulary Continuous Speech Recognition* In Proceedings of the IEEE International Conference on Acoustics, Speech, and Signal Processing, 1992, pp. 13–16.
- N. Halko, P. G. Martinsson, J. A. Tropp, *Finding Structure with Randomness: Probabilistic Algorithms for Constructing Approximate Matrix Decompositions* In SIAM Review, 2011, vol. 53, no. 2, pp. 217–288.
- W. L. Hamilton, R. Ying, J. Leskovec, *Inductive Representation Learning on Large Graphs* In Advances in Neural Information Processing Systems, 2017.
- J. Handl, J. Knowles, D. B. Kell, *Computational Cluster Validation in Post-Genomic Data Analysis* In Bioinformatics, 2005, vol. 21, no. 15, pp. 3201–3212.
- M. Hardt, B. Recht, Y. Singer, *Train Faster, Generalize Better: Stability of Stochastic Gradient Descent* In Proceedings of the 33rd International Conference on Machine Learning, 2016, pp. 1225–1234.
- T. Hastie, R. Tibshirani, *Generalized Additive Models* In Statistical Science, 1986, vol. 1, no. 3, pp. 297–310.
- T. Hastie, R. Tibshirani, J. Friedman, *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*, Springer, 2009, 2nd ed.
- A. Hauser, P. Bühlmann, *Characterization and Greedy Learning of Interventional Markov Equivalence Classes of Directed Acyclic Graphs* In Journal of Machine Learning Research, 2012, vol. 13, pp. 2409–2464.
- K. He, X. Zhang, S. Ren, J. Sun, *Deep Residual Learning for Image Recognition* In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2016, pp. 770–778.
- K. He, X. Zhang, S. Ren, J. Sun, *Delving Deep into Rectifiers: Surpassing Human-Level Performance on ImageNet Classification* In Proceedings of the IEEE International Conference on Computer Vision, 2015, pp. 1026–1034.
- M. He, Z. Wei, J.-R. Wen, *Convolutional Neural Networks on Graphs with Chebyshev Approximation, Revisited* In Advances in Neural Information Processing Systems, 2022.

- D. Heckerman, D. Geiger, D. M. Chickering, *Learning Bayesian Networks: The Combination of Knowledge and Statistical Data* In Machine Learning, 1995, vol. 20, no. 3, pp. 197–243.
- D. Hendrycks, K. Gimpel, *Gaussian Error Linear Units (GELUs)* In arXiv preprint arXiv:1606.08415, 2016.
- A. Henry, P. R. Dachapally, S. S. Pawar, Y. Chen, *Query-Key Normalization for Transformers* In Findings of the Association for Computational Linguistics: EMNLP 2020, 2020, pp. 4246–4253.
- A. Hinneburg, D. A. Keim, *An Efficient Approach to Clustering in Large Multimedia Databases with Noise* In Proceedings of the Fourth International Conference on Knowledge Discovery and Data Mining, 1998, pp. 58–65.
- G. Hinton, *A Practical Guide to Training Restricted Boltzmann Machines*, Technical Report UTML TR 2010–003, Version 1, Department of Computer Science, University of Toronto, Aug. 2, 2010.
- *Neural Networks for Machine Learning: Lecture 6*, University of Toronto, 2012, URL: https://www.cs.toronto.edu/~tijmen/csc321/slides/lecture_slides_lec6.pdf (visited on 10/04/2026).
- G. Hinton, O. Vinyals, J. Dean, *Distilling the Knowledge in a Neural Network* In arXiv preprint arXiv:1503.02531, 2015.
- G. E. Hinton, P. Dayan, B. J. Frey, R. M. Neal, *The Wake–Sleep Algorithm for Unsupervised Neural Networks* In Science, 1995, vol. 268, no. 5214, pp. 1158–1161.
- G. E. Hinton, S. Osindero, Y.-W. Teh, *A Fast Learning Algorithm for Deep Belief Nets* In Neural Computation, 2006, vol. 18, no. 7, pp. 1527–1554.
- G. E. Hinton, S. Roweis, *Stochastic Neighbor Embedding* In Advances in Neural Information Processing Systems, 2002, pp. 857–864.
- J. Ho, A. N. Jain, P. Abbeel, *Denoising Diffusion Probabilistic Models* In Advances in Neural Information Processing Systems, 2020.
- S. Hochreiter, J. Schmidhuber, *Long Short-Term Memory* In Neural Computation, 1997, vol. 9, no. 8, pp. 1735–1780.
- A. L. Hodgkin, A. F. Huxley, *A Quantitative Description of Membrane Current and Its Application to Conduction and Excitation in Nerve* In The Journal of Physiology, 1952, vol. 117, no. 4, pp. 500–544.
- A. E. Hoerl, R. W. Kennard, *Ridge Regression: Biased Estimation for Nonorthogonal Problems* In Technometrics, 1970, vol. 12, no. 1, pp. 55–67.
- E. Hoffer, I. Hubara, D. Soudry, *Train Longer, Generalize Better: Closing the Generalization Gap in Large Batch Training of Neural Networks* In Advances in Neural Information Processing Systems 30, 2017.

- M. D. Hoffman, D. M. Blei, C. Wang, J. Paisley, *Stochastic Variational Inference* In Journal of Machine Learning Research, 2013, vol. 14, no. 4, pp. 1303–1347.
- T. Hofmann, *Probabilistic Latent Semantic Analysis* In Proceedings of the Fifteenth Conference on Uncertainty in Artificial Intelligence, 1999, pp. 289–296.
- R. C. Holte, *Very Simple Classification Rules Perform Well on Most Commonly Used Datasets* In Machine Learning, 1993, vol. 11, no. 1, pp. 63–90.
- H. Hotelling, *Analysis of a complex of statistical variables into principal components*. In Journal of Educational Psychology, 1933, vol. 24, no. 6, pp. 417–441.
- H. Hotelling, *Relations between Two Sets of Variates* In Biometrika, 1936, vol. 28, no. 3-4, pp. 321–377.
- T. Hothorn, K. Hornik, A. Zeileis, *Unbiased Recursive Partitioning: A Conditional Inference Framework* In Journal of Computational and Graphical Statistics, 2006, vol. 15, no. 3, pp. 651–674.
- A. Howard, M. Sandler, G. Chu, L.-C. Chen, B. Chen, M. Tan, W. Wang, Y. Zhu, R. Pang, V. Vasudevan, Q. V. Le, H. Adam, *Searching for MobileNetV3* In arXiv preprint arXiv:1905.02244, 2019.
- G. Huang, Z. Liu, L. van der Maaten, K. Q. Weinberger, *Densely Connected Convolutional Networks* In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2017, pp. 4700–4708.
- G. Huang, Y. Sun, Z. Liu, D. Sedra, K. Q. Weinberger, *Deep Networks with Stochastic Depth* In Proceedings of the European Conference on Computer Vision, 2016, pp. 646–661.
- L. Huang, D. Yang, B. Lang, J. Deng, *Decorrelated Batch Normalization* In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2018.
- L. Huang, Y. Zhou, F. Zhu, L. Liu, L. Shao, *Iterative Normalization: Beyond Standardization towards Efficient Whitening* In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2019.
- X. Huang, S. Belongie, *Arbitrary Style Transfer in Real-time with Adaptive Instance Normalization* In Proceedings of the IEEE International Conference on Computer Vision, 2017.
- D. H. Hubel, T. N. Wiesel, *Receptive Fields, Binocular Interaction and Functional Architecture in the Cat's Visual Cortex* In The Journal of Physiology, 1962, vol. 160, no. 1, pp. 106–154.

- P. J. Huber, *Robust Estimation of a Location Parameter* In *The Annals of Mathematical Statistics*, 1964, vol. 35, no. 1, pp. 73–101.
- L. Hubert, P. Arabie, *Comparing Partitions* In *Journal of Classification*, 1985, vol. 2, no. 1, pp. 193–218.
- C. Huyen, *Designing Machine Learning Systems*, O'Reilly Media, 2022.
- A. Hyvarinen, *Fast and robust fixed-point algorithms for independent component analysis* In *IEEE Transactions on Neural Networks*, 1999, vol. 10, no. 3, pp. 626–634.
- A. Hyvärinen, *Estimation of Non-Normalized Statistical Models by Score Matching* In *Journal of Machine Learning Research*, 2005, vol. 6, no. 24, pp. 695–709.
- Intel, *Intel Builds World's Largest Neuromorphic System to Enable More Sustainable AI*, Apr. 17, 2024, URL: <https://www.intel.com/content/www/us/en/newsroom/news/intel-builds-worlds-largest-neuromorphic-system.html> (visited on 10/04/2026).
- S. Ioffe, *Batch Renormalization: Towards Reducing Minibatch Dependence in Batch-Normalized Models* In *Advances in Neural Information Processing Systems* 30, 2017.
- S. Ioffe, C. Szegedy, *Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift* In *Proceedings of the 32nd International Conference on Machine Learning*, 2015, pp. 448–456.
- E. Ising, *Beitrag zur Theorie des Ferromagnetismus* In *Zeitschrift für Physik*, 1925, vol. 31, pp. 253–258.
- P. Izmailov, D. Podoprikin, T. Garipov, D. Vetrov, A. G. Wilson, *Averaging Weights Leads to Wider Optima and Better Generalization* In *Proceedings of the 34th Conference on Uncertainty in Artificial Intelligence*, 2018, pp. 876–885.
- H. Jaeger, *Short Term Memory in Echo State Networks*, GMD Report 152, German National Research Center for Information Technology, 2001.
- *The “Echo State” Approach to Analysing and Training Recurrent Neural Networks*, GMD Report 148, German National Research Center for Information Technology, 2001.
- G. James, D. Witten, T. Hastie, R. Tibshirani, *An Introduction to Statistical Learning*, Springer, 2021, 2nd ed.
- T. Joachims, *Transductive Inference for Text Classification using Support Vector Machines* In *Proceedings of the 16th International Conference on Machine Learning*, 1999, pp. 200–209.

- W. B. Johnson, J. Lindenstrauss, *Extensions of Lipschitz mappings into a Hilbert space* In Conference in Modern Analysis and Probability, 1984, pp. 189–206.
- K. Jordan, Y. Jin, V. Boza, J. You, F. Cesista, L. Newhouse, J. Bernstein, *Muon: An Optimizer for Hidden Layers in Neural Networks*, Dec. 8, 2024, URL: <https://kellerjordan.github.io/posts/muon/> (visited on 10/04/2026).
- D. Jurafsky, J. H. Martin, *Speech and Language Processing*, Prentice Hall, 2009, 2nd ed.
- M. Kalisch, P. Bühlmann, *Estimating High-Dimensional Directed Acyclic Graphs with the PC-Algorithm* In Journal of Machine Learning Research, 2007, vol. 8, pp. 613–636.
- S. D. Kamvar, D. Klein, C. D. Manning, *Spectral Learning* In Proceedings of the Eighteenth International Joint Conference on Artificial Intelligence, 2003, pp. 561–566.
- T. Karras, T. Aila, S. Laine, J. Lehtinen, *Progressive Growing of GANs for Improved Quality, Stability, and Variation* In International Conference on Learning Representations, 2018.
- G. Karypis, E.-H. Han, V. Kumar, *Chameleon: Hierarchical Clustering Using Dynamic Modeling* In Computer, 1999, vol. 32, no. 8, pp. 68–75.
- G. V. Kass, *An Exploratory Technique for Investigating Large Quantities of Categorical Data* In Journal of the Royal Statistical Society. Series C (Applied Statistics), 1980, vol. 29, no. 2, pp. 119–127.
- A. Katharopoulos, A. Vyas, N. Pappas, F. Fleuret, *Transformers Are RNNs: Fast Autoregressive Transformers with Linear Attention* In arXiv preprint arXiv:2006.16236, 2020.
- L. Kaufman, P. J. Rousseeuw, *Clustering by Means of Medoids* In Statistical Data Analysis Based on the L1-Norm and Related Methods, 1987, pp. 405–416.
- L. Kaufman, P. J. Rousseeuw, *Finding Groups in Data: An Introduction to Cluster Analysis*, Wiley, 1990, 1st ed.
- G. Ke, Q. Meng, T. Finley, T. Wang, W. Chen, W. Ma, Q. Ye, T.-Y. Liu, *LightGBM: A Highly Efficient Gradient Boosting Decision Tree* In Advances in Neural Information Processing Systems, 2017, pp. 3146–3154.
- S. S. Keerthi, E. G. Gilbert, *Convergence of a Generalized SMO Algorithm for SVM Classifier Design* In Machine Learning, 2002, vol. 46, no. 1–3, pp. 351–360.
- C. Keribin, *Consistent Estimation of the Order of Mixture Models* In Sankhyā: The Indian Journal of Statistics, Series A, 2000, vol. 62, no. 1, pp. 49–66.

- Y. Kim, P. Panda, *Revisiting Batch Normalization for Training Low-Latency Deep Spiking Neural Networks From Scratch* In *Frontiers in Neuroscience*, 2021, vol. 15, 773954.
- D. P. Kingma, J. Ba, *Adam: A Method for Stochastic Optimization* In *International Conference on Learning Representations*, 2015.
- D. P. Kingma, P. Dhariwal, *Glow: Generative Flow with Invertible 1x1 Convolutions* In *Advances in Neural Information Processing Systems* 31, 2018.
- D. P. Kingma, M. Welling, *Auto-Encoding Variational Bayes* In *arXiv preprint arXiv:1312.6114*, 2013.
- T. N. Kipf, M. Welling, *Semi-Supervised Classification with Graph Convolutional Networks* In *International Conference on Learning Representations*, 2017.
- G. Klambauer, T. Unterthiner, A. Mayr, S. Hochreiter, *Self-Normalizing Neural Networks* In *Advances in Neural Information Processing Systems*, 2017.
- J. Kleinberg, *An Impossibility Theorem for Clustering* In *Advances in Neural Information Processing Systems*, 2002, pp. 463–470.
- M. Kleppmann, C. Riccomini, *Designing Data-Intensive Applications*, O'Reilly Media, 2026, 2nd ed.
- C. Koch, S. Ullman, *Shifts in Selective Visual Attention: Towards the Underlying Neural Circuitry* In *Human Neurobiology*, 1985, vol. 4, no. 4, pp. 219–227.
- R. Koenker, G. Bassett Jr., *Regression Quantiles* In *Econometrica*, 1978, vol. 46, no. 1, pp. 33–50.
- R. Kohavi, *The Power of Decision Tables* In *Machine Learning: ECML-95*, 1995, pp. 174–189.
- T. Kohonen, *Self-Organizing Maps*, Springer, 2001, 3rd ed.
- D. Koller, N. Friedman, *Probabilistic Graphical Models: Principles and Techniques*, MIT Press, 2009.
- V. Kolmogorov, R. Zabih, *What Energy Functions Can Be Minimized via Graph Cuts?* In *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2004, vol. 26, no. 2, pp. 147–159.
- A. Krizhevsky, I. Sutskever, G. E. Hinton, *ImageNet Classification with Deep Convolutional Neural Networks* In *Advances in Neural Information Processing Systems* 25, 2012, pp. 1097–1105.
- A. Krogh, J. Vedelsby, *Neural Network Ensembles, Cross Validation, and Active Learning* In *Advances in Neural Information Processing Systems*, 1995, pp. 231–238.

- J. B. Kruskal, *Multidimensional Scaling by Optimizing Goodness of Fit to a Nonmetric Hypothesis* In *Psychometrika*, 1964, vol. 29, no. 1, pp. 1–27.
- F. R. Kschischang, B. J. Frey, H.-A. Loeliger, *Factor Graphs and the Sum-Product Algorithm* In *IEEE Transactions on Information Theory*, 2001, vol. 47, no. 2, pp. 498–519.
- L. I. Kuncheva, C. J. Whitaker, *Measures of Diversity in Classifier Ensembles and Their Relationship with the Ensemble Accuracy* In *Machine Learning*, 2003, vol. 51, no. 2, pp. 181–207.
- W. Kwon, Z. Li, S. Zhuang, Y. Sheng, L. Zheng, C. H. Yu, J. E. Gonzalez, H. Zhang, I. Stoica, *Efficient Memory Management for Large Language Model Serving with PagedAttention* In *arXiv preprint arXiv:2309.06180*, 2023.
- M. J. van der Laan, E. C. Polley, A. E. Hubbard, *Super Learner* In *Statistical Applications in Genetics and Molecular Biology*, 2007, vol. 6, no. 1, pp. Article 25.
- B. M. Lake, R. Salakhutdinov, J. B. Tenenbaum, *Human-level Concept Learning through Probabilistic Program Induction* In *Science*, 2015, vol. 350, no. 6266, pp. 1332–1338.
- G. N. Lance, W. T. Williams, *A General Theory of Classificatory Sorting Strategies: 1. Hierarchical Systems* In *The Computer Journal*, 1967, vol. 9, no. 4, pp. 373–380.
- N. Landwehr, M. Hall, E. Frank, *Logistic Model Trees* In *Machine Learning*, 2005, vol. 59, no. 1-2, pp. 161–205.
- H. Larochelle, I. Murray, *The Neural Autoregressive Distribution Estimator* In *Proceedings of the Fourteenth International Conference on Artificial Intelligence and Statistics*, 2011, pp. 29–37.
- K. G. Larsen, J. Nelson, *Optimality of the Johnson–Lindenstrauss Lemma* In *Proceedings of the 58th IEEE Annual Symposium on Foundations of Computer Science*, 2017, pp. 633–638.
- S. L. Lauritzen, D. J. Spiegelhalter, *Local Computations with Probabilities on Graphical Structures and Their Application to Expert Systems* In *Journal of the Royal Statistical Society: Series B (Methodological)*, 1988, vol. 50, no. 2, pp. 157–194.
- S. L. Lauritzen, *Graphical Models*, Clarendon Press, 1996.
- A. Lavin, S. Gray, *Fast Algorithms for Convolutional Neural Networks* In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 2016, pp. 4013–4021.

- N. D. Lawrence, *Learning for Larger Datasets with the Gaussian Process Latent Variable Model* In Proceedings of the Eleventh International Conference on Artificial Intelligence and Statistics, 2007, pp. 243–250.
- N. D. Lawrence, *Probabilistic Non-linear Principal Component Analysis with Gaussian Process Latent Variable Models* In Journal of Machine Learning Research, 2005, vol. 6, no. 60, pp. 1783–1816.
- Y. LeCun, L. Bottou, Y. Bengio, P. Haffner, *Gradient-Based Learning Applied to Document Recognition* In Proceedings of the IEEE, 1998, vol. 86, no. 11, pp. 2278–2324.
- D. D. Lee, H. S. Seung, *Algorithms for Non-negative Matrix Factorization* In Advances in Neural Information Processing Systems, 2000, pp. 556–562.
- D. D. Lee, H. S. Seung, *Learning the parts of objects by non-negative matrix factorization* In Nature, 1999, vol. 401, no. 6755, pp. 788–791.
- J. de Leeuw, P. Mair, *Multidimensional Scaling Using Majorization: SMACOF in R* In Journal of Statistical Software, 2009, vol. 31, no. 3, pp. 1–30.
- M. Leshno, V. Y. Lin, A. Pinkus, S. Schocken, *Multilayer Feedforward Networks with a Nonpolynomial Activation Function Can Approximate Any Function* In Neural Networks, 1993, vol. 6, no. 6, pp. 861–867.
- W. B. Levy, V. G. Calvert, *Communication Consumes 35 Times More Energy than Computation in the Human Cortex, but Both Costs Are Needed to Predict Synapse Number* In Proceedings of the National Academy of Sciences, 2021, vol. 118, no. 18, e2008173118.
- Y.-F. Li, Z.-H. Zhou, *Towards Making Unlabeled Data Never Hurt* In Proceedings of the 28th International Conference on Machine Learning, 2011, pp. 1081–1088.
- G. Li, C. Xiong, A. Thabet, B. Ghanem, *DeeperGCN: All You Need to Train Deeper GCNs* In arXiv preprint arXiv:2006.07739, 2020.
- K.-C. Li, *Sliced Inverse Regression for Dimension Reduction* In Journal of the American Statistical Association, 1991, vol. 86, no. 414, pp. 316–327.
- P. Li, T. J. Hastie, K. W. Church, *Very sparse random projections* In Proceedings of the 12th ACM SIGKDD international conference on Knowledge discovery and data mining, 2006, pp. 287–296.
- Y. Li, D. Tarlow, M. Brockschmidt, R. Zemel, *Gated Graph Sequence Neural Networks* In International Conference on Learning Representations, 2016.
- P. Lichtsteiner, C. Posch, T. Delbruck, *A 128×128 120 dB 15 μs Latency Asynchronous Temporal Contrast Vision Sensor* In IEEE Journal of Solid-State Circuits, 2008, vol. 43, no. 2, pp. 566–576.

- T. P. Lillicrap, A. Santoro, L. Marris, C. J. Akerman, G. Hinton, *Backpropagation and the Brain* In Nature Reviews Neuroscience, 2020, vol. 21, no. 6, pp. 335–346.
- C.-J. Lin, *Projected Gradient Methods for Nonnegative Matrix Factorization* In Neural Computation, 2007, vol. 19, no. 10, pp. 2756–2779.
- G. C. Linderman, M. Rachh, J. G. Hoskins, S. Steinerberger, Y. Kluger, *Fast Interpolation-Based t-SNE for Improved Visualization of Single-Cell RNA-seq Data* In Nature Methods, 2019, vol. 16, no. 3, pp. 243–245.
- G. C. Linderman, S. Steinerberger, *Clustering with t-SNE, Provably* In SIAM Journal on Mathematics of Data Science, 2019, vol. 1, no. 2, pp. 313–332.
- H. Liu, A. Brock, K. Simonyan, Q. V. Le, *Evolving Normalization-Activation Layers* In Advances in Neural Information Processing Systems 33, 2020.
- Y. Liu, M. Ott, N. Goyal, J. Du, M. Joshi, D. Chen, O. Levy, M. Lewis, L. Zettlemoyer, V. Stoyanov, *RoBERTa: A Robustly Optimized BERT Pretraining Approach* In arXiv preprint arXiv:1907.11692, 2019.
- S. P. Lloyd, *Least Squares Quantization in PCM* In IEEE Transactions on Information Theory, 1982, vol. 28, no. 2, pp. 129–137.
- I. Loshchilov, F. Hutter, *Decoupled Weight Decay Regularization* In International Conference on Learning Representations, 2019.
- I. Loshchilov, F. Hutter, *SGDR: Stochastic Gradient Descent with Warm Restarts* In International Conference on Learning Representations, 2017.
- P. Luo, J. Ren, Z. Peng, R. Zhang, J. Li, *Differentiable Learning-to-Normalize via Switchable Normalization* In International Conference on Learning Representations, 2019.
- T. Luong, H. Pham, C. D. Manning, *Effective Approaches to Attention-based Neural Machine Translation* In Proceedings of the 2015 Conference on Empirical Methods in Natural Language Processing, 2015, pp. 1412–1421.
- U. von Luxburg, *A Tutorial on Spectral Clustering* In Statistics and Computing, 2007, vol. 17, no. 4, pp. 395–416.
- U. von Luxburg, M. Belkin, O. Bousquet, *Consistency of Spectral Clustering* In The Annals of Statistics, 2008, vol. 36, no. 2, pp. 555–586.
- W. Maass, *Networks of Spiking Neurons: The Third Generation of Neural Network Models* In Neural Networks, 1997, vol. 10, no. 9, pp. 1659–1671.
- W. Maass, T. Natschläger, H. Markram, *Real-Time Computing Without Stable States: A New Framework for Neural Computation Based on Perturbations* In Neural Computation, 2002, vol. 14, no. 11, pp. 2531–2560.

- L. van der Maaten, *Accelerating t-SNE using Tree-Based Algorithms* In Journal of Machine Learning Research, 2014, vol. 15, no. 93, pp. 3221–3245.
- L. van der Maaten, *Learning a Parametric Embedding by Preserving Local Structure* In Proceedings of the Twelfth International Conference on Artificial Intelligence and Statistics, 2009, pp. 384–391.
- L. van der Maaten, G. Hinton, *Visualizing Data using t-SNE* In Journal of Machine Learning Research, 2008, vol. 9, no. 86, pp. 2579–2605.
- J. MacQueen, *Some Methods for Classification and Analysis of Multivariate Observations* In Proceedings of the Fifth Berkeley Symposium on Mathematical Statistics and Probability, 1967, pp. 281–297.
- M. Mahajan, P. Nimbhorkar, K. Varadarajan, *The Planar k-Means Problem Is NP-Hard* In Theoretical Computer Science, 2012, vol. 442, pp. 13–21.
- J. Mairal, F. Bach, J. Ponce, G. Sapiro, *Online Dictionary Learning for Sparse Coding* In Proceedings of the 26th Annual International Conference on Machine Learning, 2009, pp. 689–696.
- M. I. Malinen, P. Fränti, *Balanced K-Means for Clustering* In Structural, Syntactic, and Statistical Pattern Recognition, 2014, pp. 32–41.
- C. D. Manning, P. Raghavan, H. Schütze, *Introduction to Information Retrieval*, Cambridge University Press, 2008.
- V. A. Marchenko, L. A. Pastur, *Distribution of Eigenvalues for Some Sets of Random Matrices* In Mathematics of the USSR-Sbornik, 1967, vol. 1, no. 4, pp. 457–483.
- M. E. Maron, *Automatic Indexing: An Experimental Inquiry* In Journal of the ACM, 1961, vol. 8, no. 3, pp. 404–417.
- J. Martens, *New Insights and Perspectives on the Natural Gradient Method* In Journal of Machine Learning Research, 2020, vol. 21, no. 146, pp. 1–76.
- J. Martens, R. Grosse, *Optimizing Neural Networks with Kronecker-Factored Approximate Curvature* In Proceedings of the 32nd International Conference on Machine Learning, 2015, pp. 2408–2417.
- M. Mathieu, M. Henaff, Y. LeCun, *Fast Training of Convolutional Networks through FFTs* In International Conference on Learning Representations, 2014.
- A. McCallum, K. Nigam, *A Comparison of Event Models for Naive Bayes Text Classification* In Learning for Text Categorization: Papers from the 1998 Workshop, 1998, pp. 41–48.
- W. S. McCulloch, W. Pitts, *A Logical Calculus of the Ideas Immanent in Nervous Activity* In The Bulletin of Mathematical Biophysics, 1943, vol. 5, pp. 115–133.

- H. McGurk, J. MacDonald, *Hearing Lips and Seeing Voices* In *Nature*, 1976, vol. 264, no. 5588, pp. 746–748.
- L. McInnes, J. Healy, J. Melville, *UMAP: Uniform Manifold Approximation and Projection for Dimension Reduction*, 2018, arXiv: 1802.03426, URL: <https://arxiv.org/abs/1802.03426>.
- L. McInnes, J. Healy, N. Saul, L. Großberger, *UMAP: Uniform Manifold Approximation and Projection* In *Journal of Open Source Software*, 2018, vol. 3, no. 29, pp. 861.
- H. B. McMahan, G. Holt, D. Sculley, M. Young, D. Ebner, J. Grady, L. Nie, T. Phillips, E. Davydov, D. Golovin, S. Chikkerur, D. Liu, M. Wattenberg, A. M. Hrafnkelsson, T. Boulos, J. Kubica, *Ad Click Prediction: A View from the Trenches* In *Proceedings of the 19th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 2013, pp. 1222–1230.
- C. Mead, *Neuromorphic Electronic Systems* In *Proceedings of the IEEE*, 1990, vol. 78, no. 10, pp. 1629–1636.
- C. Meek, *Strong Completeness and Faithfulness in Bayesian Networks* In *Proceedings of the Eleventh Conference on Uncertainty in Artificial Intelligence*, 1995, pp. 411–418.
- M. Meilä, J. Shi, *A Random Walks View of Spectral Segmentation* In *Proceedings of the Eighth International Workshop on Artificial Intelligence and Statistics*, 2001, pp. 203–208.
- J. Mercer, *Functions of Positive and Negative Type, and Their Connection with the Theory of Integral Equations* In *Philosophical Transactions of the Royal Society of London, Series A*, 1909, vol. 209, pp. 415–446.
- S. Mika, G. Rätsch, J. Weston, B. Schölkopf, K.-R. Müller, *Fisher Discriminant Analysis with Kernels* In *Neural Networks for Signal Processing IX*, 1999, pp. 41–48.
- T. P. Minka, *Expectation Propagation for Approximate Bayesian Inference* In *Proceedings of the Seventeenth Conference on Uncertainty in Artificial Intelligence*, 2001, pp. 362–369.
- M. Minsky, S. Papert, *Perceptrons: An Introduction to Computational Geometry*, MIT Press, 1969.
- D. Misra, *Mish: A Self Regularized Non-Monotonic Activation Function* In *arXiv preprint arXiv:1908.08681*, 2019.
- T. M. Mitchell, *Machine Learning*, McGraw-Hill, 1997, 1st ed.
- T. Miyato, T. Kataoka, M. Koyama, Y. Yoshida, *Spectral Normalization for Generative Adversarial Networks* In *International Conference on Learning Representations*, 2018.

- V. Mnih, N. Heess, A. Graves, K. Kavukcuoglu, *Recurrent Models of Visual Attention* In Advances in Neural Information Processing Systems 27, 2014, pp. 2204–2212.
- M. Mohri, A. Rostamizadeh, A. Talwalkar, *Foundations of Machine Learning*, The MIT Press, 2018, 2nd ed.
- C. Morris, M. Ritzert, M. Fey, W. L. Hamilton, J. E. Lenssen, G. Rattan, M. Grohe, *Weisfeiler and Leman Go Neural: Higher-Order Graph Neural Networks* In Proceedings of the AAAI Conference on Artificial Intelligence, 2019, pp. 4602–4609.
- D. Müllner, *Modern Hierarchical, Agglomerative Clustering Algorithms*, 2011, arXiv: [1109.2378](https://arxiv.org/abs/1109.2378), URL: <https://arxiv.org/abs/1109.2378>.
- K. P. Murphy, *Machine Learning: A Probabilistic Perspective*, MIT Press, 2012.
- K. P. Murphy, *Probabilistic Machine Learning*, The MIT Press, 2023.
- K. P. Murphy, *Probabilistic Machine Learning: An Introduction*, MIT Press, 2022.
- E. A. Nadaraya, *On Estimating Regression* In Theory of Probability & Its Applications, 1964, vol. 9, no. 1, pp. 141–142.
- B. Nadler, *Finite sample approximation results for principal component analysis: A matrix perturbation approach* In The Annals of Statistics, 2008, vol. 36, no. 6, pp. 2791–2817.
- V. Nair, G. E. Hinton, *Rectified Linear Units Improve Restricted Boltzmann Machines* In Proceedings of the 27th International Conference on Machine Learning, 2010, pp. 807–814.
- National Museum of American History, *Electronic Neural Network, Mark I Perceptron*, Smithsonian Institution, URL: https://americanhistory.si.edu/collections/object/nmah_334414 (visited on 10/02/2026).
- R. M. Neal, *Markov Chain Sampling Methods for Dirichlet Process Mixture Models* In Journal of Computational and Graphical Statistics, 2000, vol. 9, no. 2, pp. 249–265.
- R. M. Neal, “MCMC Using Hamiltonian Dynamics”, in: *Handbook of Markov Chain Monte Carlo*, ed. by S. Brooks, A. Gelman, G. L. Jones, X.-L. Meng, Chapman and Hall/CRC, 2011, chap. 5, pp. 113–162.
- R. M. Neal, G. E. Hinton, “A View of the EM Algorithm That Justifies Incremental, Sparse, and Other Variants”, in: *Learning in Graphical Models*, ed. by M. I. Jordan, Dordrecht: Kluwer Academic Publishers, 1998, pp. 355–368.
- E. O. Neftci, H. Mostafa, F. Zenke, *Surrogate Gradient Learning in Spiking Neural Networks: Bringing the Power of Gradient-Based Optimization to*

- Spiking Neural Networks* In IEEE Signal Processing Magazine, 2019, vol. 36, no. 6, pp. 51–63.
- J. A. Nelder, R. W. M. Wedderburn, *Generalized Linear Models* In Journal of the Royal Statistical Society: Series A (General), 1972, vol. 135, no. 3, pp. 370–384.
- A. Y. Ng, M. I. Jordan, *On Discriminative vs. Generative Classifiers: A Comparison of Logistic Regression and Naive Bayes* In Advances in Neural Information Processing Systems 14, 2001, pp. 841–848.
- A. Y. Ng, M. I. Jordan, Y. Weiss, *On Spectral Clustering: Analysis and an Algorithm* In Advances in Neural Information Processing Systems, 2002, pp. 849–856.
- R. T. Ng, J. Han, *Efficient and Effective Clustering Methods for Spatial Data Mining* In Proceedings of the 20th International Conference on Very Large Data Bases, 1994, pp. 144–155.
- T. Q. Nguyen, J. Salazar, *Transformers without Tears: Improving the Normalization of Self-Attention* In Proceedings of the 16th International Conference on Spoken Language Translation, 2019.
- A. Niculescu-Mizil, R. Caruana, *Predicting Good Probabilities with Supervised Learning* In Proceedings of the 22nd International Conference on Machine Learning, 2005, pp. 625–632.
- K. Nigam, A. K. McCallum, S. Thrun, T. Mitchell, *Text Classification from Labeled and Unlabeled Documents using EM* In Machine Learning, 2000, vol. 39, no. 2–3, pp. 103–134.
- A. Nobel, *Histogram Regression Estimation Using Data-Dependent Partitions* In The Annals of Statistics, 1996, vol. 24, no. 3, pp. 1084–1105.
- A. B. J. Novikoff, *On Convergence Proofs for Perceptrons* In Proceedings of the Symposium on the Mathematical Theory of Automata, 1962, pp. 615–622.
- NVIDIA, *CUTLASS: Implicit GEMM Convolution*, URL: https://github.com/NVIDIA/cutlass/blob/main/media/docs/cpp/implicit_gemm_convolution.md (visited on 10/03/2026).
- B. A. Olshausen, D. J. Field, *Emergence of simple-cell receptive field properties by learning a sparse code for natural images* In Nature, 1996, vol. 381, no. 6583, pp. 607–609.
- K. Oono, T. Suzuki, *Graph Neural Networks Exponentially Lose Expressive Power for Node Classification* In International Conference on Learning Representations, 2020.

- A. van den Oord, N. Kalchbrenner, K. Kavukcuoglu, *Pixel Recurrent Neural Networks* In Proceedings of the 33rd International Conference on Machine Learning, 2016, pp. 1747–1756.
- OpenAI, *GPT-4 Technical Report* In arXiv preprint arXiv:2303.08774, 2023.
- OpenAI, *GPT-4o System Card*, OpenAI, 2024.
- *Introducing ChatGPT*, Nov. 30, 2022, URL: <https://openai.com/index/chatgpt/> (visited on 10/03/2026).
- *Introducing GPT-5*, Aug. 7, 2025, URL: <https://openai.com/index/introducing-gpt-5/> (visited on 10/03/2026).
- E. Osuna, R. Freund, F. Girosi, *An Improved Training Algorithm for Support Vector Machines* In Neural Networks for Signal Processing VII: Proceedings of the 1997 IEEE Signal Processing Society Workshop, 1997, pp. 276–285.
- L. Ouyang, J. Wu, X. Jiang, D. Almeida, C. L. Wainwright, P. Mishkin, C. Zhang, S. Agarwal, K. Slama, A. Ray, J. Schulman, J. Hilton, F. Kelton, L. Miller, M. Simens, A. Askell, P. Welinder, P. Christiano, J. Leike, R. Lowe, *Training Language Models to Follow Instructions with Human Feedback* In arXiv preprint arXiv:2203.02155, 2022.
- A. B. Owen, *Monte Carlo Theory, Methods and Examples*, Online book, 2013, URL: <https://statweb.stanford.edu/~owen/mc/>.
- P. Paatero, U. Tapper, *Positive matrix factorization: A non-negative factor model with optimal utilization of error estimates of data values* In *Environmetrics*, 1994, vol. 5, no. 2, pp. 111–126.
- G. Papamakarios, E. Nalisnick, D. J. Rezende, S. Mohamed, B. Lakshminarayanan, *Normalizing Flows for Probabilistic Modeling and Inference* In *Journal of Machine Learning Research*, 2021, vol. 22, no. 57, pp. 1–64.
- G. Papamakarios, T. Pavlakou, I. Murray, *Masked Autoregressive Flow for Density Estimation* In arXiv preprint arXiv:1705.07057, 2017.
- J. D. Park, A. Darwiche, *Complexity Results and Approximation Strategies for MAP Explanations* In *Journal of Artificial Intelligence Research*, 2004, vol. 21, pp. 101–133.
- T. Park, M.-Y. Liu, T.-C. Wang, J.-Y. Zhu, *Semantic Image Synthesis with Spatially-Adaptive Normalization* In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2019.
- L. Parsons, E. Haque, H. Liu, *Subspace Clustering for High Dimensional Data: A Review* In *ACM SIGKDD Explorations Newsletter*, 2004, vol. 6, no. 1, pp. 90–105.

- R. Pascanu, T. Mikolov, Y. Bengio, *On the Difficulty of Training Recurrent Neural Networks* In Proceedings of the 30th International Conference on Machine Learning, 2013, pp. 1310–1318.
- J. Pearl, *Probabilistic Reasoning in Intelligent Systems: Networks of Plausible Inference*, Morgan Kaufmann, 1988.
- K. Pearson, *Contributions to the Mathematical Theory of Evolution* In Philosophical Transactions of the Royal Society of London. A, 1894, vol. 185, pp. 71–110.
- K. Pearson, *On Lines and Planes of Closest Fit to Systems of Points in Space* In The London, Edinburgh, and Dublin Philosophical Magazine and Journal of Science, 1901, vol. 2, no. 11, pp. 559–572.
- W. Peebles, S. Xie, *Scalable Diffusion Models with Transformers* In Proceedings of the IEEE/CVF International Conference on Computer Vision, 2023.
- D. Peel, G. J. McLachlan, *Robust Mixture Modelling Using the t Distribution* In Statistics and Computing, 2000, vol. 10, no. 4, pp. 339–348.
- B. Peng, E. Alcaide, Q. Anthony, A. Albalak, S. Arcadinho, S. Biderman, H. Cao, X. Cheng, M. Chung, L. Derczynski, X. Du, M. Grella, K. Gv, X. He, H. Hou, P. Kazienko, J. Kocon, J. Kong, B. Koptyra, H. Lau, J. Lin, K. S. I. Mantri, F. Mom, A. Saito, G. Song, X. Tang, J. Wind, S. Woźniak, Z. Zhang, Q. Zhou, J. Zhu, R.-J. Zhu, *RWKV: Reinventing RNNs for the Transformer Era* In Findings of the Association for Computational Linguistics: EMNLP 2023, 2023, pp. 14048–14077.
- C. Peng, T. Xiao, Z. Li, Y. Jiang, X. Zhang, K. Jia, G. Yu, J. Sun, *MegDet: A Large Mini-Batch Object Detector* In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2018.
- J. Peters, J. M. Mooij, D. Janzing, B. Schölkopf, *Causal Discovery with Continuous Additive Noise Models* In Journal of Machine Learning Research, 2014, vol. 15, pp. 2009–2053.
- J. C. Platt, *Sequential Minimal Optimization: A Fast Algorithm for Training Support Vector Machines*, Technical Report MSR-TR-98-14, Microsoft Research, 1998.
- P. G. Poličar, M. Stražar, B. Zupan, *openTSNE: A Modular Python Library for t -SNE Dimensionality Reduction and Embedding* In Journal of Statistical Software, 2024, vol. 109, no. 3, pp. 1–30.
- D. Pollard, *Strong Consistency of k -Means Clustering* In The Annals of Statistics, 1981, vol. 9, no. 1, pp. 135–140.

- O. Press, N. A. Smith, M. Lewis, *Train Short, Test Long: Attention with Linear Biases Enables Input Length Extrapolation* In arXiv preprint arXiv:2108.12409, 2021.
- L. Prokhorenkova, G. Gusev, A. Vorobev, A. V. Dorogush, A. Gulin, *CatBoost: Unbiased Boosting with Categorical Features* In Advances in Neural Information Processing Systems, 2018, pp. 6638–6648.
- D. Purves, G. J. Augustine, D. Fitzpatrick, L. C. Katz, A.-S. LaMantia, J. O. McNamara, S. M. Williams, eds. *Neuroscience*, Sinauer Associates, 2001, 2nd ed.
- PyTorch Contributors, *Hardsigmoid*, URL: <https://docs.pytorch.org/docs/2.14/generated/torch.nn.Hardsigmoid.html> (visited on 10/02/2026).
- S. Qiao, H. Wang, C. Liu, W. Shen, A. Yuille, *Micro-Batch Training with Batch-Channel Normalization and Weight Standardization* In Proceedings of the European Conference on Computer Vision, 2020.
- Z. Qiu, Z. Wang, B. Zheng, Z. Huang, K. Wen, S. Yang, R. Men, L. Yu, F. Huang, S. Huang, D. Liu, J. Zhou, J. Lin, *Gated Attention for Large Language Models: Non-linearity, Sparsity, and Attention-Sink-Free* In arXiv preprint arXiv:2505.06708, 2025.
- J. R. Quinlan, *Learning with Continuous Classes* In Proceedings of AI'92, 1992, pp. 343–348.
- J. R. Quinlan, *C4.5: Programs for Machine Learning*, Morgan Kaufmann, 1993, 1st ed.
- J. R. Quinlan, *Improved Use of Continuous Attributes in C4.5* In Journal of Artificial Intelligence Research, 1996, vol. 4, pp. 77–90.
- J. R. Quinlan, *Induction of Decision Trees* In Machine Learning, 1986, vol. 1, no. 1, pp. 81–106.
- A. Radford, J. W. Kim, C. Hallacy, A. Ramesh, G. Goh, S. Agarwal, G. Sasstry, A. Askell, P. Mishkin, J. Clark, G. Krueger, I. Sutskever, *Learning Transferable Visual Models from Natural Language Supervision* In Proceedings of the 38th International Conference on Machine Learning, 2021, pp. 8748–8763.
- A. Radford, K. Narasimhan, T. Salimans, I. Sutskever, *Improving Language Understanding by Generative Pre-Training*, OpenAI, 2018.
- A. Radford, J. Wu, R. Child, D. Luan, D. Amodei, I. Sutskever, *Language Models Are Unsupervised Multitask Learners*, OpenAI, 2019.
- C. Raffel, N. Shazeer, A. Roberts, K. Lee, S. Narang, M. Matena, Y. Zhou, W. Li, P. J. Liu, *Exploring the Limits of Transfer Learning with a Unified Text-*

- to-Text Transformer* In Journal of Machine Learning Research, 2020, vol. 21, no. 140, pp. 1–67.
- M. E. Raichle, D. A. Gusnard, *Appraising the Brain's Energy Budget* In Proceedings of the National Academy of Sciences, 2002, vol. 99, no. 16, pp. 10237–10239.
- P. Ramachandran, B. Zoph, Q. V. Le, *Searching for Activation Functions* In arXiv preprint arXiv:1710.05941, 2017.
- C. R. Rao, *The Utilization of Multiple Measurements in Problems of Biological Classification* In Journal of the Royal Statistical Society: Series B (Methodological), 1948, vol. 10, no. 2, pp. 159–193.
- K. V. Rashmi, A. Gilad-Bachrach, *DART: Dropouts Meet Multiple Additive Regression Trees* In Proceedings of the Eighteenth International Conference on Artificial Intelligence and Statistics, 2015, pp. 489–497.
- C. E. Rasmussen, C. K. I. Williams, *Gaussian Processes for Machine Learning*, MIT Press, 2006.
- S. J. Reddi, S. Kale, S. Kumar, *On the Convergence of Adam and Beyond* In International Conference on Learning Representations, 2018.
- J. D. M. Rennie, L. Shih, J. Teevan, D. R. Karger, *Tackling the Poor Assumptions of Naive Bayes Text Classifiers* In Proceedings of the Twentieth International Conference on Machine Learning, 2003, pp. 616–623.
- D. Rezende, S. Mohamed, *Variational Inference with Normalizing Flows* In Proceedings of the 32nd International Conference on Machine Learning, 2015, pp. 1530–1538.
- M. Richardson, P. Domingos, *Markov Logic Networks* In Machine Learning, 2006, vol. 62, no. 1–2, pp. 107–136.
- R. A. Rigby, D. M. Stasinopoulos, *Generalized Additive Models for Location, Scale and Shape* In Journal of the Royal Statistical Society: Series C (Applied Statistics), 2005, vol. 54, no. 3, pp. 507–554.
- G. O. Roberts, J. S. Rosenthal, *General State Space Markov Chains and MCMC Algorithms* In Probability Surveys, 2004, vol. 1, pp. 20–71.
- R. T. Rockafellar, *Convex Analysis*, Princeton University Press, 1970.
- Y. Romano, E. Patterson, E. J. Candès, *Conformalized Quantile Regression* In arXiv preprint arXiv:1905.03222, 2019.
- R. Rombach, A. Blattmann, D. Lorenz, P. Esser, B. Ommer, *High-Resolution Image Synthesis with Latent Diffusion Models* In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2022, pp. 10684–10695.

- O. Ronneberger, P. Fischer, T. Brox, *U-Net: Convolutional Networks for Biomedical Image Segmentation* In Medical Image Computing and Computer-Assisted Intervention, 2015, pp. 234–241.
- F. Rosenblatt, *The Perceptron: A Probabilistic Model for Information Storage and Organization in the Brain* In Psychological Review, 1958, vol. 65, no. 6, pp. 386–408.
- E. Rossi, B. Chamberlain, F. Frasca, D. Eynard, F. Monti, M. Bronstein, *Temporal Graph Networks for Deep Learning on Dynamic Graphs* In arXiv preprint arXiv:2006.10637, 2020.
- P. J. Rousseeuw, *Silhouettes: A Graphical Aid to the Interpretation and Validation of Cluster Analysis* In Journal of Computational and Applied Mathematics, 1987, vol. 20, pp. 53–65.
- S. T. Roweis, L. K. Saul, *Nonlinear Dimensionality Reduction by Locally Linear Embedding* In Science, 2000, vol. 290, no. 5500, pp. 2323–2326.
- D. B. Rubin, *Inference and Missing Data* In Biometrika, 1976, vol. 63, no. 3, pp. 581–592.
- D. B. Rubin, *Inference and Missing Data* In Biometrika, 1976, vol. 63, no. 3, pp. 581–592.
- H. Rue, L. Held, *Gaussian Markov Random Fields: Theory and Applications*, Chapman and Hall/CRC, 2005, 1st ed.
- B. Rueckauer, I.-A. Lungu, Y. Hu, M. Pfeiffer, S.-C. Liu, *Conversion of Continuous-Valued Deep Networks to Efficient Event-Driven Networks for Image Classification* In Frontiers in Neuroscience, 2017, vol. 11, 682.
- RuleQuest Research, *Is See5/C5.0 Better Than C4.5?*, Feb. 2017, URL: <https://www.rulequest.com/see5-comparison.html> (visited on 10/02/2026).
- D. E. Rumelhart, G. E. Hinton, R. J. Williams, *Learning representations by back-propagating errors* In Nature, 1986, vol. 323, no. 6088, pp. 533–536.
- T. Sainburg, L. McInnes, T. Q. Gentner, *Parametric UMAP Embeddings for Representation and Semisupervised Learning* In Neural Computation, 2021, vol. 33, no. 11, pp. 2881–2907.
- H. Sak, A. Senior, F. Beaufays, *Long Short-Term Memory Based Recurrent Neural Network Architectures for Large Vocabulary Speech Recognition* In arXiv preprint arXiv:1402.1128, 2014.
- T. Salimans, I. Goodfellow, W. Zaremba, V. Cheung, A. Radford, X. Chen, *Improved Techniques for Training GANs* In Advances in Neural Information Processing Systems 29, 2016.
- T. Salimans, J. Ho, *Progressive Distillation for Fast Sampling of Diffusion Models* In International Conference on Learning Representations, 2022.

- T. Salimans, D. P. Kingma, *Weight Normalization: A Simple Reparameterization to Accelerate Training of Deep Neural Networks* In Advances in Neural Information Processing Systems 29, 2016.
- J. W. Sammon Jr., *A Nonlinear Mapping for Data Structure Analysis* In IEEE Transactions on Computers, 1969, vol. 18, no. 5, pp. 401–409.
- M. Sandler, A. Howard, M. Zhu, A. Zhmoginov, L.-C. Chen, *MobileNetV2: Inverted Residuals and Linear Bottlenecks* In arXiv preprint arXiv:1801.04381, 2018.
- S. Santurkar, D. Tsipras, A. Ilyas, A. Madry, *How Does Batch Normalization Help Optimization?* In Advances in Neural Information Processing Systems 31, 2018, pp. 2483–2493.
- S. Sarawagi, W. W. Cohen, *Semi-Markov Conditional Random Fields for Information Extraction* In Advances in Neural Information Processing Systems, 2004.
- S. Särkkä, L. Svensson, *Bayesian Filtering and Smoothing*, Cambridge University Press, 2023, 2nd ed.
- V. G. Satorras, E. Hoogeboom, M. Welling, *$E(n)$ Equivariant Graph Neural Networks* In Proceedings of the 38th International Conference on Machine Learning, 2021, pp. 9323–9332.
- F. Scarselli, M. Gori, A. C. Tsoi, M. Hagenbuchner, G. Monfardini, *The Graph Neural Network Model* In IEEE Transactions on Neural Networks, 2009, vol. 20, no. 1, pp. 61–80.
- M. Schlichtkrull, T. N. Kipf, P. Bloem, R. van den Berg, I. Titov, M. Welling, *Modeling Relational Data with Graph Convolutional Networks* In The Semantic Web, 2018, pp. 593–607.
- J. Schmidhuber, R. Huber, *Learning to Generate Artificial Fovea Trajectories for Target Detection* In International Journal of Neural Systems, 1991, vol. 2, no. 1–2, pp. 135–141.
- B. Schölkopf, R. Herbrich, A. J. Smola, *A Generalized Representer Theorem* In Computational Learning Theory, 2001, pp. 416–426.
- B. Schölkopf, A. J. Smola, R. C. Williamson, P. L. Bartlett, *New Support Vector Algorithms* In Neural Computation, 2000, vol. 12, no. 5, pp. 1207–1245.
- B. Schölkopf, A. Smola, K.-R. Müller, *Nonlinear Component Analysis as a Kernel Eigenvalue Problem* In Neural Computation, 1998, vol. 10, no. 5, pp. 1299–1319.
- E. Schubert, P. J. Rousseeuw, *Faster k -Medoids Clustering: Improving the PAM, CLARA, and CLARANS Algorithms* In Similarity Search and Applications, 2019, pp. 171–187.

- E. Schubert, J. Sander, M. Ester, H.-P. Kriegel, X. Xu, *DBSCAN Revisited, Revisited: Why and How You Should (Still) Use DBSCAN* In ACM Transactions on Database Systems, 2017, vol. 42, no. 3, pp. 1–21.
- scikit-learn developers, *Clustering*, scikit-learn User Guide, URL: <https://scikit-learn.org/stable/modules/clustering.html> (visited on 10/04/2026).
- *ComplementNB API Documentation, Version 1.9.1*, 2026, URL: https://scikit-learn.org/stable/modules/generated/sklearn.naive_bayes.ComplementNB.html (visited on 10/03/2026).
- *Decomposing Signals in Components*, scikit-learn User Guide, URL: <https://scikit-learn.org/stable/modules/decomposition.html> (visited on 10/04/2026).
- E. Scornet, G. Biau, J.-P. Vert, *Consistency of Random Forests* In The Annals of Statistics, 2015, vol. 43, no. 4, pp. 1716–1741.
- H. J. Scudder III, *Probability of Error of Some Adaptive Pattern-Recognition Machines* In IEEE Transactions on Information Theory, 1965, vol. 11, no. 3, pp. 363–371.
- D. Sculley, *Web-Scale k-Means Clustering* In Proceedings of the 19th International Conference on World Wide Web, 2010, pp. 1177–1178.
- H. Sedghi, V. Gupta, P. M. Long, *The Singular Values of Convolutional Layers* In International Conference on Learning Representations, 2019.
- R. D. Shachter, *Bayes-Ball: The Rational Pastime (for Determining Irrelevance and Requisite Information in Belief Networks and Influence Diagrams)* In Proceedings of the Fourteenth Conference on Uncertainty in Artificial Intelligence, 1998, pp. 480–487.
- S. Shalev-Shwartz, S. Ben-David, *Understanding Machine Learning: From Theory to Algorithms*, Cambridge University Press, 2014, 1st ed.
- P. Shaw, J. Uszkoreit, A. Vaswani, *Self-Attention with Relative Position Representations* In Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 2 (Short Papers), 2018, pp. 464–468.
- N. Shazeer, *Fast Transformer Decoding: One Write-Head Is All You Need* In arXiv preprint arXiv:1911.02150, 2019.
- N. Shazeer, *GLU Variants Improve Transformer* In arXiv preprint arXiv:2002.05202, 2020.
- N. Shazeer, A. Mirhoseini, K. Maziarz, A. Davis, Q. Le, G. Hinton, J. Dean, *Outrageously Large Neural Networks: The Sparsely-Gated Mixture-of-Experts Layer* In arXiv preprint arXiv:1701.06538, 2017.

- N. Shazeer, M. Stern, *Adafactor: Adaptive Learning Rates with Sublinear Memory Cost* In Proceedings of the 35th International Conference on Machine Learning, 2018, pp. 4596–4604.
- G. Sheikholeslami, S. Chatterjee, A. Zhang, *WaveCluster: A Multi-Resolution Clustering Approach for Very Large Spatial Databases* In Proceedings of the 24th International Conference on Very Large Data Bases, 1998, pp. 428–439.
- S. Shen, Z. Yao, A. Gholami, M. W. Mahoney, K. Keutzer, *PowerNorm: Rethinking Batch Normalization in Transformers* In Proceedings of the 37th International Conference on Machine Learning, 2020, pp. 8741–8751.
- J. Shi, J. Malik, *Normalized Cuts and Image Segmentation* In IEEE Transactions on Pattern Analysis and Machine Intelligence, 2000, vol. 22, no. 8, pp. 888–905.
- S. Shimizu, P. O. Hoyer, A. Hyvärinen, A. Kerminen, *A Linear Non-Gaussian Acyclic Model for Causal Discovery* In Journal of Machine Learning Research, 2006, vol. 7, pp. 2003–2030.
- S. Shleifer, J. Weston, M. Ott, *NormFormer: Improved Transformer Pretraining with Extra Normalization* In arXiv preprint arXiv:2110.09456, 2021.
- V. de Silva, J. B. Tenenbaum, *Global Versus Local Methods in Nonlinear Dimensionality Reduction* In Advances in Neural Information Processing Systems, 2002, pp. 705–712.
- K. Simonyan, A. Zisserman, *Very Deep Convolutional Networks for Large-Scale Image Recognition* In International Conference on Learning Representations, 2015.
- A. Singer, H.-T. Wu, *Vector Diffusion Maps and the Connection Laplacian* In Communications on Pure and Applied Mathematics, 2012, vol. 65, no. 8, pp. 1067–1144.
- S. Singh, S. Krishnan, *Filter Response Normalization Layer: Eliminating Batch Dependence in the Training of Deep Neural Networks* In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2020, pp. 11237–11246.
- A. J. Smola, B. Schölkopf, *A Tutorial on Support Vector Regression* In Statistics and Computing, 2004, vol. 14, no. 3, pp. 199–222.
- J. Sohl-Dickstein, E. Weiss, N. Maheswaranathan, S. Ganguli, *Deep Unsupervised Learning using Nonequilibrium Thermodynamics* In Proceedings of the 32nd International Conference on Machine Learning, 2015, pp. 2256–2265.

- Y. Song, J. Sohl-Dickstein, D. P. Kingma, A. Kumar, S. Ermon, B. Poole, *Score-Based Generative Modeling through Stochastic Differential Equations* In International Conference on Learning Representations, 2021.
- D. Soudry, E. Hoffer, M. S. Nacson, S. Gunasekar, N. Srebro, *The Implicit Bias of Gradient Descent on Separable Data* In Journal of Machine Learning Research, 2018, vol. 19, no. 70, pp. 1–57.
- C. Spearman, “*General Intelligence*,” *Objectively Determined and Measured* In The American Journal of Psychology, 1904, vol. 15, no. 2, pp. 201–292.
- N. Srivastava, G. Hinton, A. Krizhevsky, I. Sutskever, R. Salakhutdinov, *Dropout: A Simple Way to Prevent Neural Networks from Overfitting* In Journal of Machine Learning Research, 2014, vol. 15, no. 56, pp. 1929–1958.
- R. K. Srivastava, K. Greff, J. Schmidhuber, *Highway Networks* In ICML Deep Learning Workshop, 2015.
- B. E. Stein, T. R. Stanford, B. A. Rowland, *Development of Multisensory Integration from the Perspective of the Individual Neuron* In Nature Reviews Neuroscience, 2014, vol. 15, no. 8, pp. 520–535.
- M. Steinbach, G. Karypis, V. Kumar, *A Comparison of Document Clustering Techniques*, tech. rep. 00-034, University of Minnesota, 2000.
- H. Steinhaus, *Sur la division des corps matériels en parties* In Bulletin de l’Académie Polonaise des Sciences, Classe III, 1957, vol. 4, no. 12, pp. 801–804.
- S. M. Stigler, *Gauss and the Invention of Least Squares* In The Annals of Statistics, 1981, vol. 9, no. 3, pp. 465–474.
- C. J. Stone, *Consistent Nonparametric Regression* In The Annals of Statistics, 1977, vol. 5, no. 4, pp. 595–620.
- C. J. Stone, *Consistent Nonparametric Regression* In The Annals of Statistics, 1977, vol. 5, no. 4, pp. 595–620.
- C. J. Stone, M. H. Hansen, C. Kooperberg, Y. K. Truong, *Polynomial Splines and Their Tensor Products in Extended Linear Modeling: 1994 Wald Memorial Lecture* In The Annals of Statistics, 1997, vol. 25, no. 4, pp. 1371–1470.
- V. Strassen, *Gaussian Elimination Is Not Optimal* In Numerische Mathematik, 1969, vol. 13, no. 4, pp. 354–356.
- A. Strehl, J. Ghosh, *Cluster Ensembles—A Knowledge Reuse Framework for Combining Multiple Partitions* In Journal of Machine Learning Research, 2002, vol. 3, pp. 583–617.

- C. Strobl, A.-L. Boulesteix, A. Zeileis, T. Hothorn, *Bias in Random Forest Variable Importance Measures: Illustrations, Sources and a Solution* In BMC Bioinformatics, 2007, vol. 8, pp. 25.
- J. Su, Y. Lu, S. Pan, A. Murtadha, B. Wen, Y. Liu, *RoFormer: Enhanced Transformer with Rotary Position Embedding* In arXiv preprint arXiv:2104.09864, 2021.
- I. Sutskever, T. Tieleman, *On the Convergence Properties of Contrastive Divergence* In Proceedings of the Thirteenth International Conference on Artificial Intelligence and Statistics, 2010, pp. 789–795.
- I. Sutskever, O. Vinyals, Q. V. Le, *Sequence to Sequence Learning with Neural Networks* In Advances in Neural Information Processing Systems, 2014.
- C. Sutton, A. McCallum, *An Introduction to Conditional Random Fields* In Foundations and Trends in Machine Learning, 2012, vol. 4, no. 4, pp. 267–373.
- R. S. Sutton, A. G. Barto, *Reinforcement Learning: An Introduction*, MIT Press, 2018, 2nd ed.
- C. Szegedy, W. Liu, Y. Jia, P. Sermanet, S. Reed, D. Anguelov, D. Erhan, V. Vanhoucke, A. Rabinovich, *Going Deeper with Convolutions* In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2015, pp. 1–9.
- C. Szegedy, W. Zaremba, I. Sutskever, J. Bruna, D. Erhan, I. Goodfellow, R. Fergus, *Intriguing Properties of Neural Networks* In arXiv preprint arXiv:1312.6199, 2014.
- R. Szeliski, *Computer Vision*, Springer, 2022, 2nd ed.
- C. Szepesvári, *Algorithms for Reinforcement Learning*, Morgan & Claypool Publishers, 2010.
- K. S. Tai, R. Socher, C. D. Manning, *Improved Semantic Representations From Tree-Structured Long Short-Term Memory Networks* In Proceedings of the 53rd Annual Meeting of the Association for Computational Linguistics and the 7th International Joint Conference on Natural Language Processing, 2015, pp. 1556–1566.
- J. Tang, J. Liu, M. Zhang, Q. Mei, *Visualizing Large-Scale and High-Dimensional Data* In Proceedings of the 25th International Conference on World Wide Web, 2016, pp. 287–297.
- B. Taskar, P. Abbeel, D. Koller, *Discriminative Probabilistic Models for Relational Data* In Proceedings of the Eighteenth Conference on Uncertainty in Artificial Intelligence, 2002, pp. 485–492.

- Y. W. Teh, M. I. Jordan, M. J. Beal, D. M. Blei, *Hierarchical Dirichlet Processes* In Journal of the American Statistical Association, 2006, vol. 101, no. 476, pp. 1566–1581.
- M. Telgarsky, *Benefits of Depth in Neural Networks* In Proceedings of the 29th Annual Conference on Learning Theory, 2016, pp. 1517–1539.
- J. B. Tenenbaum, V. de Silva, J. C. Langford, *A Global Geometric Framework for Nonlinear Dimensionality Reduction* In Science, 2000, vol. 290, no. 5500, pp. 2319–2323.
- R. Tibshirani, *Regression Shrinkage and Selection via the Lasso* In Journal of the Royal Statistical Society: Series B (Methodological), 1996, vol. 58, no. 1, pp. 267–288.
- R. Tibshirani, G. Walther, T. Hastie, *Estimating the Number of Clusters in a Data Set via the Gap Statistic* In Journal of the Royal Statistical Society: Series B (Statistical Methodology), 2001, vol. 63, no. 2, pp. 411–423.
- M. E. Tipping, *Sparse Bayesian Learning and the Relevance Vector Machine* In Journal of Machine Learning Research, 2001, vol. 1, pp. 211–244.
- M. E. Tipping, C. M. Bishop, *Mixtures of Probabilistic Principal Component Analyzers* In Neural Computation, 1999, vol. 11, no. 2, pp. 443–482.
- M. E. Tipping, C. M. Bishop, *Probabilistic Principal Component Analysis* In Journal of the Royal Statistical Society: Series B (Statistical Methodology), 1999, vol. 61, no. 3, pp. 611–622.
- M. K. Titsias, *Variational Learning of Inducing Variables in Sparse Gaussian Processes* In Proceedings of the Twelfth International Conference on Artificial Intelligence and Statistics, 2009, pp. 567–574.
- M. K. Titsias, N. D. Lawrence, *Bayesian Gaussian Process Latent Variable Model* In Proceedings of the Thirteenth International Conference on Artificial Intelligence and Statistics, 2010, pp. 844–851.
- W. S. Torgerson, *Multidimensional Scaling: I. Theory and Method* In Psychometrika, 1952, vol. 17, no. 4, pp. 401–419.
- T. Ullmann, C. Hennig, A.-L. Boulesteix, *Validation of Cluster Analysis Results on Validation Data: A Systematic Framework* In WIREs Data Mining and Knowledge Discovery, 2022, vol. 12, no. 3, e1444.
- D. Ulyanov, A. Vedaldi, V. Lempitsky, *Instance Normalization: The Missing Ingredient for Fast Stylization* In arXiv preprint arXiv:1607.08022, 2016.
- A. W. van der Vaart, *Asymptotic Statistics*, Cambridge University Press, 1998.
- A. W. van der Vaart, J. H. van Zanten, *Rates of Contraction of Posterior Distributions Based on Gaussian Process Priors* In The Annals of Statistics, 2008, vol. 36, no. 3, pp. 1435–1463.

- C. Varin, N. Reid, D. Firth, *An Overview of Composite Likelihood Methods* In *Statistica Sinica*, 2011, vol. 21, pp. 5–42.
- A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, Ł. Kaiser, I. Polosukhin, *Attention Is All You Need* In *Advances in Neural Information Processing Systems* 30, 2017, pp. 5998–6008.
- A. Vehtari, A. Gelman, D. Simpson, B. Carpenter, P.-C. Bürkner, *Rank-Normalization, Folding, and Localization: An Improved $\hat{R}$ for Assessing Convergence of MCMC* In *Bayesian Analysis*, 2021, vol. 16, no. 2, pp. 667–718.
- P. Veličković, G. Cucurull, A. Casanova, A. Romero, P. Liò, Y. Bengio, *Graph Attention Networks* In *International Conference on Learning Representations*, 2018.
- K. Wagstaff, C. Cardie, S. Rogers, S. Schroedl, *Constrained K-Means Clustering with Background Knowledge* In *Proceedings of the Eighteenth International Conference on Machine Learning*, 2001, pp. 577–584.
- M. J. Wainwright, T. S. Jaakkola, A. S. Willsky, *A New Class of Upper Bounds on the Log Partition Function* In *IEEE Transactions on Information Theory*, 2005, vol. 51, no. 7, pp. 2313–2335.
- M. J. Wainwright, T. S. Jaakkola, A. S. Willsky, *MAP Estimation via Agreement on Trees: Message-Passing and Linear Programming* In *IEEE Transactions on Information Theory*, 2005, vol. 51, no. 11, pp. 3697–3717.
- M. J. Wainwright, M. I. Jordan, *Graphical Models, Exponential Families, and Variational Inference* In *Foundations and Trends in Machine Learning*, 2008, vol. 1, no. 1–2, pp. 1–305.
- L. Wan, M. Zeiler, S. Zhang, Y. Le Cun, R. Fergus, *Regularization of Neural Networks Using DropConnect* In *Proceedings of the 30th International Conference on Machine Learning*, 2013, pp. 1058–1066.
- B. A. Wandell, S. O. Dumoulin, A. A. Brewer, *Visual Field Maps in Human Cortex* In *Neuron*, 2007, vol. 56, no. 2, pp. 366–383.
- H. Wang, S. Ma, L. Dong, S. Huang, D. Zhang, F. Wei, *DeepNet: Scaling Transformers to 1,000 Layers* In *arXiv preprint arXiv:2203.00555*, 2022.
- S. Wang, B. Z. Li, M. Khabsa, H. Fang, H. Ma, *Linformer: Self-Attention with Linear Complexity* In *arXiv preprint arXiv:2006.04768*, 2020.
- W. Wang, J. Yang, R. R. Muntz, *STING: A Statistical Information Grid Approach to Spatial Data Mining* In *Proceedings of the 23rd International Conference on Very Large Data Bases*, 1997, pp. 186–195.
- Y. Wang, H. Huang, C. Rudin, Y. Shaposhnik, *Understanding How Dimension Reduction Tools Work: An Empirical Approach to Deciphering t-SNE*,

- UMAP, TriMap, and PaCMAP for Data Visualization* In Journal of Machine Learning Research, 2021, vol. 22, no. 201, pp. 1–73.
- J. H. Ward Jr., *Hierarchical Grouping to Optimize an Objective Function* In Journal of the American Statistical Association, 1963, vol. 58, no. 301, pp. 236–244.
- G. S. Watson, *Smooth Regression Analysis* In Sankhyā: The Indian Journal of Statistics, Series A, 1964, vol. 26, no. 4, pp. 359–372.
- G. I. Webb, J. R. Boughton, Z. Wang, *Not So Naive Bayes: Aggregating One-Dependence Estimators* In Machine Learning, 2005, vol. 58, no. 1, pp. 5–24.
- K. Q. Weinberger, L. K. Saul, *Distance Metric Learning for Large Margin Nearest Neighbor Classification* In Journal of Machine Learning Research, 2009, vol. 10, no. 9, pp. 207–244.
- K. Q. Weinberger, L. K. Saul, *Unsupervised Learning of Image Manifolds by Semidefinite Programming* In International Journal of Computer Vision, 2006, vol. 70, no. 1, pp. 77–90.
- A. C. Wilson, R. Roelofs, M. Stern, N. Srebro, B. Recht, *The Marginal Value of Adaptive Gradient Methods in Machine Learning* In Advances in Neural Information Processing Systems 30, 2017, pp. 4148–4158.
- J. Winn, C. M. Bishop, *Variational Message Passing* In Journal of Machine Learning Research, 2005, vol. 6, no. 23, pp. 661–694.
- J. H. Wolfe, *Pattern Clustering by Multivariate Mixture Analysis* In Multivariate Behavioral Research, 1970, vol. 5, no. 3, pp. 329–350.
- D. H. Wolpert, *Stacked Generalization* In Neural Networks, 1992, vol. 5, no. 2, pp. 241–259.
- S. Woo, S. Debnath, R. Hu, X. Chen, Z. Liu, I. S. Kweon, S. Xie, *ConvNeXt V2: Co-designing and Scaling ConvNets with Masked Autoencoders* In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2023.
- S. N. Wood, *Fast Stable Restricted Maximum Likelihood and Marginal Likelihood Estimation of Semiparametric Generalized Linear Models* In Journal of the Royal Statistical Society: Series B (Statistical Methodology), 2011, vol. 73, no. 1, pp. 3–36.
- K. Woods, W. P. Kegelmeyer, K. Bowyer, *Combination of Multiple Classifiers Using Local Accuracy Estimates* In IEEE Transactions on Pattern Analysis and Machine Intelligence, 1997, vol. 19, no. 4, pp. 405–410.
- C. F. J. Wu, *On the Convergence Properties of the EM Algorithm* In The Annals of Statistics, 1983, vol. 11, no. 1, pp. 95–103.

- Y. Wu, K. He, *Group Normalization* In Proceedings of the European Conference on Computer Vision, 2018, pp. 3–19.
- E. P. Xing, A. Y. Ng, M. I. Jordan, S. Russell, *Distance Metric Learning with Application to Clustering with Side-Information* In Advances in Neural Information Processing Systems, 2003, pp. 521–528.
- R. Xiong, Y. Yang, D. He, K. Zheng, S. Zheng, C. Xing, H. Zhang, Y. Lan, L. Wang, T.-Y. Liu, *On Layer Normalization in the Transformer Architecture* In arXiv preprint arXiv:2002.04745, 2020.
- B. Xu, N. Wang, T. Chen, M. Li, *Empirical Evaluation of Rectified Activations in Convolutional Network* In arXiv preprint arXiv:1505.00853, 2015.
- K. Xu, J. Ba, R. Kiros, K. Cho, A. Courville, R. Salakhudinov, R. Zemel, Y. Bengio, *Show, Attend and Tell: Neural Image Caption Generation with Visual Attention* In Proceedings of the 32nd International Conference on Machine Learning, 2015, pp. 2048–2057.
- K. Xu, W. Hu, J. Leskovec, S. Jegelka, *How Powerful Are Graph Neural Networks?* In International Conference on Learning Representations, 2019.
- J. S. Yedidia, W. T. Freeman, Y. Weiss, *Constructing Free Energy Approximations and Generalized Belief Propagation Algorithms* In IEEE Transactions on Information Theory, 2005, vol. 51, no. 7, pp. 2282–2312.
- I. B. Yildiz, H. Jaeger, S. J. Kiebel, *Re-Visiting the Echo State Property* In Neural Networks, 2012, vol. 35, pp. 1–9.
- G. Young, A. S. Householder, *Discussion of a Set of Points in Terms of Their Mutual Distances* In Psychometrika, 1938, vol. 3, no. 1, pp. 19–22.
- M. Yuan, Y. Lin, *Model Selection and Estimation in Regression with Grouped Variables* In Journal of the Royal Statistical Society: Series B (Statistical Methodology), 2006, vol. 68, no. 1, pp. 49–67.
- S. Yun, D. Han, S. J. Oh, S. Chun, J. Choe, Y. Yoo, *CutMix: Regularization Strategy to Train Strong Classifiers with Localizable Features* In Proceedings of the IEEE/CVF International Conference on Computer Vision, 2019, pp. 6023–6032.
- M. D. Zeiler, *ADADELTA: An Adaptive Learning Rate Method* In arXiv preprint arXiv:1212.5701, 2012.
- A. Zhang, Z. C. Lipton, M. Li, A. J. Smola, *Dive into Deep Learning*, Cambridge University Press, 2023.
- B. Zhang, R. Sennrich, *Root Mean Square Layer Normalization* In arXiv preprint arXiv:1910.07467, 2019.
- H. Zhang, *The Optimality of Naive Bayes* In Proceedings of the Seventeenth International Florida Artificial Intelligence Research Society Conference, 2004, pp. 562–567.

- H. Zhang, M. Cisse, Y. N. Dauphin, D. Lopez-Paz, *mixup: Beyond Empirical Risk Minimization* In International Conference on Learning Representations, 2018.
- J. Zhang, *Causal Reasoning with Ancestral Graphs* In Journal of Machine Learning Research, 2008, vol. 9, pp. 1437–1474.
- J. Zhang, *On the Completeness of Orientation Rules for Causal Discovery in the Presence of Latent Confounders and Selection Bias* In Artificial Intelligence, 2008, vol. 172, no. 16–17, pp. 1873–1896.
- R. Zhang, P. Isola, A. A. Efros, *Colorful Image Colorization* In Proceedings of the European Conference on Computer Vision, 2016, pp. 649–666.
- T. Zhang, R. Ramakrishnan, M. Livny, *BIRCH: An Efficient Data Clustering Method for Very Large Databases* In Proceedings of the ACM SIGMOD International Conference on Management of Data, 1996, pp. 103–114.
- Z. Zhang, H. Zha, *Principal Manifolds and Nonlinear Dimensionality Reduction via Tangent Space Alignment* In SIAM Journal on Scientific Computing, 2004, vol. 26, no. 1, pp. 313–338.
- L. Zhao, L. Akoglu, *PairNorm: Tackling Oversmoothing in GNNs* In International Conference on Learning Representations, 2020.
- P. Zhao, B. Yu, *On Model Selection Consistency of Lasso* In Journal of Machine Learning Research, 2006, vol. 7, no. 90, pp. 2541–2563.
- X. Zheng, B. Aragam, P. Ravikumar, E. P. Xing, *DAGs with NO TEARS: Continuous Optimization for Structure Learning* In Advances in Neural Information Processing Systems, 2018.
- D. Zhou, O. Bousquet, T. N. Lal, J. Weston, B. Schölkopf, *Learning with Local and Global Consistency* In Advances in Neural Information Processing Systems, 2003, pp. 321–328.
- Z. Zhou, Y. Zhu, C. He, Y. Wang, S. Yan, Y. Tian, L. Yuan, *Spikformer: When Spiking Neural Network Meets Transformer* In International Conference on Learning Representations, 2023.
- Z.-H. Zhou, M. Li, *Tri-Training: Exploiting Unlabeled Data Using Three Classifiers* In IEEE Transactions on Knowledge and Data Engineering, 2005, vol. 17, no. 11, pp. 1529–1541.
- J. Zhu, X. Chen, K. He, Y. LeCun, Z. Liu, *Transformers without Normalization* In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2025, pp. 14901–14911.
- X. Zhu, Z. Ghahramani, *Learning from Labeled and Unlabeled Data with Label Propagation*, tech. rep. CMU-CALD-02-107, Carnegie Mellon University, June 2002.

- X. Zhu, Z. Ghahramani, J. Lafferty, *Semi-Supervised Learning Using Gaussian Fields and Harmonic Functions* In Proceedings of the Twentieth International Conference on Machine Learning, 2003, pp. 912–919.
- H. Zou, T. Hastie, *Regularization and Variable Selection via the Elastic Net* In Journal of the Royal Statistical Society: Series B (Statistical Methodology), 2005, vol. 67, no. 2, pp. 301–320.
- H. Zou, T. Hastie, R. Tibshirani, *Sparse Principal Component Analysis* In Journal of Computational and Graphical Statistics, 2006, vol. 15, no. 2, pp. 265–286.
- 周志华, 机器学习, 清华大学出版社, 2016, 1st ed.
- 李航, 统计学习方法, 清华大学出版社, 2019, 2nd ed.
- 邱锡鹏, 神经网络与深度学习, 机械工业出版社, 2020.

索引

- AR 诊断, R-hat diagnostic, 827
- 一对一, one-vs-one, 96
- 一对其余, one-vs-rest, 96
- 一维 Weisfeiler–Leman 检验, 1-dimensional Weisfeiler–Leman test, 489
- 一致性, consistency, 70, 806
- 三角化, triangulation, 757
- 三训练, tri-training, 161
- 上下文学习, in-context learning, 539
- 上下文特定参数化, context-specific parameterization, 675
- 上采样, upsampling, 422
- 下颞皮层, inferotemporal cortex, 325
- 不动点, fixed point, 491
- 不可约, irreducible, 926
- 不可约性, irreducibility, 812
- 不可表示条件, irrepresentable condition, 26
- 不可识别性, non-identifiability, 854
- 不应期, refractory period, 584
- ϵ 不敏感损失, ϵ -insensitive loss, 30
- 不纯度下降重要性, impurity-decrease importance, 292
- 专家, expert, 564
- 两切片动态有向图模型, two-slice temporal Bayesian network, 923
- 严格平稳性, strict stationarity, 924
- 严格正有限离散模型, strictly positive finite discrete model, 667
- 中央沟, central sulcus, 324
- 中心样本, medoid, 173
- 中枢神经系统, central nervous system, 323
- 主动实验设计, active experimental design, 876
- 主成分分析, principal component analysis, 220
- 主成分回归, principal component regression, 28
- 主成分方向, principal component directions, 220
- 主成分追踪, principal component pursuit, 224
- 事件序列, event sequence, 495
- 事件相机, event camera, 592
- 二分 K-means, Bisecting K-means, 176
- 二次判别分析, quadratic discriminant analysis, 67
- 互信息, mutual information, 858
- 互可达距离, mutual reachability distance, 186
- 互斥特征捆绑, exclusive feature bundling, 300
- 互相关, cross-correlation, 381
- 互补松弛, complementary slackness, 84
- 交叉注意力, cross-attention, 517
- 交叉熵损失, cross-entropy loss, 126
- 交替 Gibbs 采样, alternating Gibbs sampling, 908
- 交替方向乘法, alternating direction method of multipliers, 225
- 交集性质, intersection property, 686
- 人工神经网络, artificial neural network, 316
- 人工网络到脉冲网络转换, ANN-to-SNN conversion, 590
- 代价复杂度剪枝, cost-complexity pruning, 49, 117
- 仿射耦合层, affine coupling layer, 951
- 优化, optimization, 317
- 优化误差, optimization error, 853
- 伪似然, pseudolikelihood, 835, 870
- 伪标签, pseudo-label, 144
- 伪残差, pseudo-residual, 297
- 伪边缘, pseudomarginal, 786
- 伯努利朴素贝叶斯, Bernoulli naive Bayes, 132
- 似然加权, likelihood weighting, 809
- 位置编码, positional encoding, 510
- 低密度分离假设, low-density separation assumption, 156
- 低秩注意力, low-rank attention, 554
- 作用域, scope, 724, 731
- 依赖性映射, dependency map, 708
- 保守的, conservative, 874
- 保序回归, isotonic regression, 99
- 信任度, trustworthiness, 283
- 信息增益, information gain, 113
- 信息增益率, gain ratio, 114

- 信用分配, credit assignment, 327
- 信赖域, trust region, 609
- 灰质, gray matter, 324
- 点积注意力, dot-product attention, 445
- 点预测, point prediction, 652
- 熵, entropy, 113
- 熵最小化, entropy minimization, 147
- 父节点, parent, 660
- 牛顿法, Newton's method, 609
- 特征图, feature map, 386
- 特征投影, feature projection, 373
- 特征映射, feature mapping, 3
- 状态空间模型, state space model, 335, 448, 923
- 狄利克雷先验, Dirichlet prior, 833
- 狄利克雷分布, Dirichlet distribution, 131
- 狄利克雷能量, Dirichlet energy, 153
- 狄利克雷过程混合, Dirichlet process mixture, 207, 898
- 独立性映射, independency map, 708
- 独立成分分析, independent component analysis, 227, 873
- 独立提议, independence proposal, 813
- 环置信传播, loopy belief propagation, 786
- 玻尔兹曼机, Boltzmann machine, 907
- 生成对抗网络, generative adversarial network, 965
- 生成模型, generative model, 845
- 电导, conductance, 190
- 电突触, electrical synapse, 323
- 留一法, leave-one-out, 90
- 病态曲率, ill-conditioned curvature, 597
- 白化, whitening, 228, 617
- 白质, white matter, 324
- 目标泄漏, target leakage, 301
- 直接密度可达, directly density-reachable, 178
- 直接采样, direct sampling, 807
- 直推学习, transductive learning, 155, 481
- 直推支持向量机, transductive support vector machine, 154
- 相关向量机, relevance vector machine, 100
- 相对位置编码, relative positional encoding, 547
- 相异度, dissimilarity, 11
- 瞬时变量变换公式, instantaneous change of variables, 953
- 硬 Sigmoid, hard sigmoid, 343
- 硬 Swish, hard swish, 349
- 硬 Tanh, hard tanh, 344
- 硬复位, hard reset, 585
- 硬注意力, hard attention, 507
- 硬钳制, hard clamping, 149
- 硬间隔, hard margin, 82
- 确定性节点, deterministic node, 675
- 确认偏差, confirmation bias, 147
- 碰撞节点, collider, 665
- 祖先, ancestor, 660
- 祖先图, ancestral graph, 705
- 祖先道德图检测, ancestral moral graph test, 670
- 祖先采样, ancestral sampling, 677, 807
- 祖先闭包, ancestral closure, 705
- 神经元, neuron, 322
- 神经参数化, neural parameterization, 657
- 神经形态电子系统, neuromorphic electronic systems, 580
- 神经能量模型, neural energy-based model, 909
- 神经自回归分布估计器, neural autoregressive distribution estimator, 885
- 神经递质, neurotransmitter, 323
- 离散卷积, discrete convolution, 378
- 积分发放模型, integrate-and-fire model, 585
- 积分自相关时间, integrated autocorrelation time, 826
- 稀疏 Cholesky 分解, sparse Cholesky factorization, 750
- 稀疏 PCA, sparse PCA, 223
- 稀疏加低秩分解, sparse plus low-rank decomposition, 871
- 稀疏注意力, sparse attention, 553
- 稀疏组 Lasso, sparse group Lasso, 27
- 稀疏编码, sparse coding, 233
- 空洞卷积, dilated convolution, 383
- 空腔分布, cavity distribution, 792
- 空间 Dropout, spatial dropout, 648
- 空间自适应归一化, SPADE, 620
- 空间通路, where pathway, 325
- 突触, synapse, 322, 587
- 突触可塑性, synaptic plasticity, 326
- 窥孔连接, peephole connections, 443
- 端到端学习, end-to-end learning, 319
- 符号嵌入, symbol embedding, 430
- 符号微分, symbolic differentiation, 364
- 等效样本量, equivalent sample size, 862
- 等距映射, isometric mapping, 245
- 算子融合, operator fusion, 399
- 簇内平方误差, sum of squared errors, 168
- 类内散度矩阵, within-class scatter matrix, 67
- 类别平衡约束, class-balance constraint, 155
- 类间散度矩阵, between-class scatter matrix, 68
- 粒子, particle, 818
- 粒子滤波, particle filtering, 818, 941
- 精度矩阵, precision matrix, 700, 737, 869, 906
- 精确推断, exact inference, 656, 657

- 系统性偏差, systematic bias, 599
- 系统重采样, systematic resampling, 820
- 紧凑模型, compact model, 309
- 累计解释方差, cumulative explained variance, 221
- 纠错输出码, error-correcting output codes, 97
- 约束块, chunklet, 209
- 线性偏置注意力, attention with linear biases, 548
- 线性判别分析, linear discriminant analysis, 66
- 线性时不变, linear time-invariant, 448
- 线性核, linear kernel, 8
- 线性注意力, linear attention, 554
- 线性规划松弛, linear programming relaxation, 798
- 线性链条件随机场, linear-chain CRF, 914
- 线性非高斯无环模型, linear non-Gaussian acyclic model, 873
- 线性高斯条件分布, linear Gaussian conditional distribution, 676
- 线性高斯状态空间模型, linear Gaussian state space model, 932
- 线搜索, line search, 609
- 组 Lasso, group Lasso, 21
- 组归一化, group normalization, 403, 624
- 细致平衡, detailed balance, 811
- 经典 MDS, classical MDS, 240
- 经验 Fisher, empirical Fisher, 612
- 结构 Hamming 距离, structural Hamming distance, 879
- 结构一致性, structural consistency, 877
- 结构化变分推断, structured variational inference, 781
- 结构化感知机, structured perceptron, 79
- 结构化核, structured kernel, 10
- 结构化状态空间序列模型, structured state space sequence model, 335, 452
- 结构学习, structure learning, 656, 856
- 结构期望最大化, structural expectation maximization, 864
- 结构风险最小化, structural risk minimization, 90
- 绝对位置编码, absolute positional encoding, 511
- 统一流形逼近与投影, uniform manifold approximation and projection, 264
- 统计信息网络, STatistical INformation Grid, 192
- 统计误差, statistical error, 853
- 维数灾难, curse of dimensionality, 282
- 编码器, encoder, 526, 946
- 编码器—解码器, encoder-decoder, 422, 430, 526
- 缩放指数线性单元, scaled exponential linear unit, 346
- 缩放点积注意力, scaled dot-product attention, 513
- 缺失值, missing value, 830
- 缺失机制, missingness mechanism, 846
- 置信度, confidence, 144
- 置换不变性, permutation invariance, 474
- 置换矩阵, permutation matrix, 474
- 置换等变性, permutation equivariance, 474
- 置换重要性, permutation importance, 292
- 耦合参数, coupling parameter, 904
- 聚合后验, aggregated posterior, 949
- 聚类, clustering, 167
- 聚类特征, clustering feature, 200
- 背侧视觉通路, dorsal visual stream, 325
- 胶质细胞, glial cell, 322
- 能力估计预测, competence-estimation prediction, 310
- 能量函数, energy function, 692, 902
- 脉冲时序依赖可塑性, spike-timing-dependent plasticity, 326, 588
- 脉冲神经网络, spiking neural network, 329, 579
- 腹侧视觉通路, ventral visual stream, 325
- 膜电位, membrane potential, 322, 584
- 自举粒子滤波, bootstrap particle filter, 821
- 自动微分, automatic differentiation, 364, 853
- 自助重采样, bootstrap, 879
- 自回归密度模型, autoregressive density model, 884
- 自回归模型, autoregressive model, 472
- 自回归流, autoregressive flow, 952
- 自归一化网络, self-normalizing neural network, 346
- 自归一化重要性采样, self-normalized importance sampling, 808
- 自注意力, self-attention, 335, 506
- 自然参数, natural parameter, 776
- 自然梯度, natural gradient, 611, 783
- 自环, self-loop, 476
- 自由支持向量, free support vector, 94
- 自由能, free energy, 907
- 自训练, self-training, 144
- 自适应 LayerNorm, AdaLN, 623
- 自适应学习率, adaptive learning rate, 604
- 自适应实例归一化, AdaIN, 623
- 自适应指数积分发放, adaptive exponential integrate-and-fire, 585
- 范数惩罚, norm penalty, 641
- 落地, grounding, 911
- 蒙特卡洛估计, Monte Carlo estimation, 805
- 蒙特卡洛标准误, Monte Carlo standard error, 806
- 虚拟批归一化, virtual batch normalization, 619
- 蛙跳积分, leapfrog integration, 816
- 补集朴素贝叶斯, complement naive Bayes, 141
- 表示学习, representation learning, 317

- 表示能力, representational capacity, 317
- 表达性, expressivity, 367
- 袋外样本, out-of-bag sample, 290
- 袋外预测, out-of-bag prediction, 310
- 被动攻击算法, passive-aggressive algorithm, 79
- 装袋法, bootstrap aggregating, 13, 290, 649
- 覆盖, cover, 118
- 观测变量, observed variable, 830
- 观测完整, complete observed data, 831
- 规则模型, rule-based model, 12
- 规范化流, normalizing flow, 950
- 规范形式, canonical form, 736
- 视网膜, retina, 324
- 视觉 Transformer, Vision Transformer, 576
- 解码器, decoder, 526, 945
- 解释消除, explaining away, 664
- 计数数, counting number, 788
- 训练敏感性, training sensitivity, 638
- 记忆容量, memory capacity, 438
- 证据下界, evidence lower bound, 279, 775, 840
- 评分函数, scoring function, 373
- 识别模型, recognition model, 845
- 词元, token, 510
- 诚实分区, honest partitioning, 50
- 误差反向传播, error backpropagation, 330
- 诱导变量, inducing variables, 57
- 诱导图, induced graph, 745
- 诱导子图, induced subgraph, 680
- 诱导宽度, induced width, 746
- 诱导点, inducing point, 279
- 读出, readout, 436, 477
- 调整兰德指数, adjusted Rand index, 216
- 谱归一化, spectral normalization, 627
- 谱滤波, spectral filtering, 484
- 谱聚类, spectral clustering, 187
- 贝叶斯 GPLVM, Bayesian GPLVM, 279
- 贝叶斯 PPCA, Bayesian PPCA, 280
- 贝叶斯一致性, Bayes consistency, 109
- 贝叶斯信息准则, Bayesian information criterion, 860
- 贝叶斯加性回归树, Bayesian additive regression trees, 61
- 贝叶斯模型平均, Bayesian model averaging, 862
- 贝叶斯狄利克雷等价评分, Bayesian Dirichlet equivalent score, 862
- 贝叶斯线性回归, Bayesian linear regression, 54
- 贝叶斯网络, Bayesian network, 660
- 贝叶斯风险, Bayes risk, 105
- 贝塔分布, Beta distribution, 132
- 负采样, negative sampling, 129, 266
- 责任度, responsibility, 202, 889
- 质量矩阵, mass matrix, 815
- 贪心干预等价搜索, greedy interventional equivalence search, 874
- 贪心搜索, greedy search, 113
- 贪心等价搜索, greedy equivalence search, 863
- 资格迹, eligibility trace, 589
- 赫布学习, Hebbian learning, 326, 588
- 赫布定律, Hebb's rule, 330
- 超图, hypergraph, 495
- 超边, hyperedge, 495
- 跨步卷积, strided convolution, 382
- 路径, path, 664, 680
- 路由器, router, 564
- 跳跃连接, skip connection, 422
- 转移核, transition kernel, 811
- 转置卷积, transposed convolution, 384
- 轮廓系数, silhouette coefficient, 215
- 软注意力, soft attention, 507
- 软间隔, soft margin, 92
- 软阈值, soft thresholding, 24
- 输入标准化, input standardization, 616
- 输入:, Input:, 74, 86, 115, 120, 133, 145, 151, 157, 198, 209, 363, 387, 590, 610, 669, 677, 734, 740, 764, 781, 816, 821, 842, 909, 928, 960
- 输出:, Output:, 74, 86, 115, 120, 134, 145, 151, 157, 198, 209, 363, 387, 590, 610, 669, 677, 734, 740, 764, 781, 816, 821, 842, 909, 928, 960
- 边界点, border point, 178
- 边缘似然, marginal likelihood, 57, 839, 861
- 边缘化, marginalization, 653, 732
- 边缘多面体, marginal polytope, 777
- 边缘最大后验推断, marginal maximum a posteriori inference, 741
- 过压缩, oversquashing, 500
- 过平滑, oversmoothing, 498
- 过渡层, transition layer, 417
- 运行交集性质, running intersection property, 759
- 运行均值, running mean, 618
- 运行方差, running variance, 618
- 近似推断, approximate inference, 656
- 近似族误差, variational approximation error, 948
- 近似最近邻检索, approximate nearest-neighbor search, 104
- 近邻传播, Affinity Propagation, 191

- 近邻成分分析, neighbourhood components analysis, 104
连续值激活, continuous-valued activation, 338
连续卷积, continuous convolution, 378
连续性, continuity, 283
连续规范化流, continuous normalizing flow, 953
连通分量, connected component, 680
迭代归一化, IterNorm, 617
迭代重加权最小二乘, iteratively reweighted least squares, 35, 127
退化解, degenerate solution, 853
退化问题, degradation problem, 414
退火, annealing, 157
适当评分, proper scoring rule, 63
逆自回归流, inverse autoregressive flow, 953
逐位置前馈网络, position-wise feed-forward network, 523
逐位置变换, position-wise transformation, 373
逐层预训练, layer-wise pretraining, 376
逐点卷积, pointwise convolution, 401
通用矩阵乘法, general matrix multiplication, 387
通用逼近, universal approximation, 367
通道, channel, 376
通道混合, channel mixing, 460
逻辑模型树, logistic model tree, 122
遍历性, ergodicity, 926
道德化, moralization, 705
道德图, moral graph, 705
遮蔽语言模型, masked language model, 532
邻域, neighborhood, 11, 473
邻居采样, neighbor sampling, 481
邻居集合, neighborhood, 679
邻接矩阵, adjacency matrix, 473
郎飞结, node of Ranvier, 322
部分 RMSNorm, pRMSNorm, 622
部分汇聚, partial pooling, 894
部分祖先图, partial ancestral graph, 872
酉矩阵, unitary matrix, 634
配分函数, partition function, 689, 902
采样蒸馏, sampling distillation, 963
重参数化梯度, reparameterization gradient, 785
重叠保留, overlap-save, 397
重叠相加, overlap-add, 397
重新参数化, reparameterization, 726
重要性采样, importance sampling, 808
重采样, resampling, 820
铰链函数, hinge function, 51
链接函数, link function, 34
链接方式, linkage, 197
锐度感知最小化, sharpness-aware minimization, 645
键, key, 513
键值缓存, key-value cache, 551
长度外推, length extrapolation, 470, 574
长期依赖, long-term dependency, 434
长短期记忆, long short-term memory, 334, 440
门控图神经网络, gated graph neural network, 492
门控循环单元, gated recurrent unit, 443
门控注意力, gated attention, 552
门控线性单元, gated linear unit, 563
门控连接, gated connection, 631
间接卷积, indirect convolution, 399
间隔打散, margin shattering, 89
阶跃函数, step function, 342
阻尼, damping, 609
降维, dimensionality reduction, 219
随时间反向传播, backpropagation through time, 432
随机化带泄漏 ReLU, randomized leaky ReLU, 345
随机变分推断, stochastic variational inference, 784
随机微分方程, stochastic differential equation, 960
随机投影, random projection, 234
随机方差, stochastic variance, 599
随机权重平均, stochastic weight averaging, 643
随机梯度, stochastic gradient, 852
随机梯度下降, stochastic gradient descent, 127, 601
随机森林, random forest, 292
随机深度, stochastic depth, 648
随机缺失, missing at random, 276, 846
随机邻居嵌入, stochastic neighbor embedding, 257
隐半 Markov 模型, hidden semi-Markov model, 931
隐式 GEMM, implicit GEMM, 399
隐式偏置, implicit bias, 643
隐式分布, implicit distribution, 965
隐式微分, implicit differentiation, 493
隐状态, hidden state, 321, 426
隐藏层, hidden layer, 316
隐马尔可夫模型, hidden Markov model, 926
雅可比矩阵, Jacobian matrix, 434
集成学习, ensemble learning, 13, 286
集成模型, ensemble model, 287
零回避, zero avoiding, 776
零强制, zero forcing, 776
零阶保持离散化, zero-order hold discretization, 449
静态成员选择, static ensemble selection, 307
非周期性, aperiodicity, 812, 926

- 非度量 MDS, nonmetric MDS, 241
- 非负矩阵分解, nonnegative matrix factorization, 230
- 非退化线性高斯模型, nondegenerate linear Gaussian model, 667
- 非随机缺失, missing not at random, 846
- 鞍点, saddle point, 595
- 顺序覆盖, sequential covering, 119
- 预条件, preconditioning, 597
- 预测, prediction, 924
- 预测分布, predictive distribution, 652
- 预激活值, pre-activation, 340
- 预热, warmup, 602
- 频率编码, rate coding, 583
- 饱和, saturation, 343
- 首次发放时间编码, time-to-first-spike coding, 583
- 马氏距离, Mahalanobis distance, 104
- 驻点, stationary point, 595
- 验证数据, validation data, 215
- 验证预测, validation prediction, 310
- 骨架, skeleton, 705, 856
- 髓鞘, myelin sheath, 322
- 高斯 Markov 随机场, Gaussian Markov random field, 700, 906
- 高斯判别分析, Gaussian discriminant analysis, 137
- 高斯径向基核, Gaussian radial basis function kernel, 9
- 高斯朴素贝叶斯, Gaussian naive Bayes, 132
- 高斯混合模型, Gaussian mixture model, 201, 889
- 高斯误差线性单元, Gaussian error linear unit, 348
- 高斯过程, Gaussian process, 277
- 高斯过程回归, Gaussian process regression, 54
- 高斯过程潜变量模型, Gaussian process latent variable model, 277
- 高阶 HMM, higher-order HMM, 931
- 高阶势, higher-order potential, 911
- 高阶图网络, higher-order graph neural network, 496
- 高阶多项式投影, high-order polynomial projection operators, 450
- 高阶条件随机场, higher-order CRF, 917
- 鲁棒 PCA, robust PCA, 224
- ActNorm, 628
- AdaBoost, 295
- Adafactor, 607
- AdamW, 646
- AMSGrad, 607
- Baum-Welch 算法, Baum-Welch algorithm, 929
- Bayes-ball 算法, Bayes-ball algorithm, 669
- Bayes 因子, Bayes factor, 861
- BERT, Bidirectional Encoder Representations from Transformers, 532
- Bethe 自由能, Bethe free energy, 787
- Blending, 305
- Boosting, 13, 294
- CatBoost, 301
- Cauchy 核, Cauchy kernel, 454
- Crammer-Singer 多类 SVM, Crammer-Singer multiclass SVM, 98
- CutMix, 639
- Dirichlet 能量, Dirichlet energy, 251
- DropBlock, 648
- DropConnect, 647
- Dropout, 646
- d-分离, d-separated, 665
- EvoNorm, 621
- fan-in, 357
- fan-out, 357
- Fisher 信息矩阵, Fisher information matrix, 611
- Fisher 判别准则, Fisher discriminant criterion, 68
- Fisher 评分, Fisher scoring, 35
- FixNorm, 622
- FlashAttention, 557
- GEGLU, GELU-gated linear unit, 563
- Gibbs 采样, Gibbs sampling, 813
- Glorot 初始化, Glorot initialization, 358
- GPT, generative pre-trained transformer, 536
- Gram 矩阵, Gram matrix, 4
- GraphNorm, 628
- Hammersley-Clifford 定理, Hammersley-Clifford theorem, 694
- Hessian LLE, 268
- Hessian 矩阵, Hessian matrix, 595
- He 初始化, He initialization, 359
- Highway 网络, Highway network, 415
- Huber 损失, Huber loss, 20
- Inception 模块, Inception module, 409

Ising 模型, Ising model, 699, 903

K 中位数聚类, K-medians, 176

K 中心样本聚类, K-medoids, 173

Kalman 增益, Kalman gain, 933

Kalman 滤波, Kalman filtering, 933

Karush–Kuhn–Tucker 条件, Karush–Kuhn–Tucker conditions, 84

Kesler 构造, Kesler construction, 77

Kikuchi 自由能, Kikuchi free energy, 789

K-means++, 170

K 均值聚类, K-means, 168

Laplacian 核, Laplacian kernel, 9

Lasso, 21

LightGBM, 299

Lion, 609

Logistic 函数, logistic function, 343

Logistic 回归, logistic regression, 124

logit, 354

Mamba, 456

Markov 假设, Markov assumption, 924

Markov 毯, Markov blanket, 662, 681, 814

Markov 等价类, Markov equivalence class, 856

Markov 逻辑网络, Markov logic network, 911

Markov 链, Markov chain, 925

Markov 链蒙特卡洛, Markov chain Monte Carlo, 811

Markov 随机场, Markov random field, 680

Maxout 单元, maxout unit, 349

MessageNorm, 628

Metropolis–Hastings 方法, Metropolis–Hastings, 812

Metropolis 校正, Metropolis correction, 816

Mish 函数, Mish function, 348

Mixup, 639

Möbius 分解, Möbius decomposition, 695

M-估计, M-estimation, 20

m-分离, m-separation, 872

Nadaraya–Watson 核平滑, Nadaraya–Watson kernel smoothing, 46

Nesterov 加速方法, Nesterov accelerated gradient, 604

NJW 算法, Ng–Jordan–Weiss algorithm, 188

Nyström 近似, Nyström approximation, 154

PairNorm, 628

PC 算法, PC algorithm, 859

PixelNorm, 622

Platt 缩放, Platt scaling, 98

Potts 模型, Potts model, 699, 905

PowerNorm, 620

Rao–Blackwell 化, Rao–Blackwellization, 810

Rao–Blackwell 化粒子滤波, Rao–Blackwellized particle filtering, 823

Rauch–Tung–Striebel 平滑, Rauch–Tung–Striebel smoothing, 934

ReLU6 函数, ReLU6 function, 345

ReZero, 568

RoBERTa, 534

same 填充, same padding, 382

Sammon 映射, Sammon mapping, 242

ScaleNorm, 622

Schur 补, Schur complement, 738

Sigmoid 函数, sigmoid function, 125

Sigmoid 加权线性单元, sigmoid-weighted linear unit, 347

Sigmoid 核, sigmoid kernel, 10

Slater 条件, Slater’s condition, 83

SMACOF, scaling by majorizing a complicated function, 242

Softmax 变换, softmax transformation, 350

Softmax 回归, softmax regression, 128

Softplus 函数, softplus function, 347

Softsign 函数, softsign function, 344

Stacking, 13, 303

Super Learner, 306

ν -SVM, nu-support vector machine, 101

SwiGLU, 563

Swish 函数, Swish function, 347

T5, Text-to-Text Transfer Transformer, 541

Transformer, 334, 506

t-SNE, 261

valid 填充, valid padding, 382

值, value, 513

倾斜分布, tilted distribution, 792

偏最小二乘回归, partial least squares regression, 28

储备池计算, reservoir computing, 436

像素卷积自回归模型, PixelCNN, 886

元学习器, meta-learner, 13, 303

充分统计量, sufficient statistic, 776, 833

- 光滑性, smoothness, 964
- 全图训练, full-graph training, 481
- 全局 Markov 性质, global Markov property, 665, 684
- 全局响应归一化, GRN, 628
- 全局平均池化, global average pooling, 402
- 全局极小点, global minimum, 595
- 全局注意力, global attention, 446
- 全连接, fully connected, 337
- 全连接层, fully connected layer, 341
- 共识聚类, consensus clustering, 208
- 共轭, conjugacy, 131
- 共轭先验, conjugate prior, 849
- 关系图卷积网络, relational graph convolutional network, 494
- 关系模板, relational template, 911
- 关联扫描, associative scan, 449
- 关联矩阵, incidence matrix, 495
- 典型相关分析, canonical correlation analysis, 225
- 内容通路, what pathway, 325
- 内蕴高斯 Markov 随机场, intrinsic GMRF, 702
- 再生核 Hilbert 空间, reproducing kernel Hilbert space, 6
- 决策树, decision tree, 12
- 决策表, decision table, 124
- 决策边界, decision boundary, 65
- 凝聚分析, Agglomerative Nesting, 196
- 几何持续时间, geometric duration, 931
- 几何遍历性, geometric ergodicity, 825
- 几何间隔, geometric margin, 81
- 几率, odds, 125
- 函数间隔, functional margin, 81
- 分位数回归, quantile regression, 28
- 分位数损失, pinball loss, 28
- 分发, distribute, 755
- 分块, tiling, 399
- 分块 Gibbs 采样, blocked Gibbs sampling, 815
- 分层重采样, stratified resampling, 820
- 分布估计, posterior inference, 848
- 分布变化, distribution shift, 637
- 分布回归, distributional regression, 53
- 分布外泛化, out-of-distribution generalization, 574
- 分布式表示, distributed representation, 319
- 分数, score, 958
- 分数函数估计, score-function estimator, 785
- 分数匹配, score matching, 837
- 分类, classification, 65
- 分类与回归树, classification and regression trees, 47, 116
- 分类头, classification head, 373
- 分组卷积, grouped convolution, 401
- 分组查询注意力, grouped-query attention, 559
- 分裂分析, Divisive Analysis, 199
- 分裂群, splinter group, 200
- 分隔集, separator, 759
- 分隔集势, separator potential, 763
- 分页注意力, PagedAttention, 561
- 切换线性动态系统, switching linear dynamical system, 939
- 切比雪夫多项式, Chebyshev polynomial, 486
- 初级视觉皮层, primary visual cortex, 324
- 前向-后向算法, forward-backward algorithm, 927
- 前向模式, forward mode, 365
- 前向消息, forward message, 914
- 前缀注意力, prefix attention, 552
- 前置层归一化, pre-layer normalization, 524
- 前馈神经网络, feedforward neural network, 335
- 先驱集合, predecessor set, 660
- 剪枝, pruning, 112
- 加性噪声模型, additive noise model, 873
- 加性注意力, additive attention, 445
- 加权 k 近邻, weighted k -nearest neighbors, 110
- 动作电位, action potential, 322
- 动态 Tanh, DyT, 629
- 动态分类器选择, dynamic classifier selection, 308
- 动态图, dynamic graph, 494
- 动态有向图模型, dynamic Bayesian network, 922
- 动态集成选择, dynamic ensemble selection, 308
- 动量刷新, momentum refreshment, 815
- 动量法, momentum, 603
- 势函数, potential function, 688, 902
- 勿连约束, cannot-link, 208
- 化学突触, chemical synapse, 322
- 区域, region, 788
- 半 Markov 条件随机场, semi-Markov CRF, 916
- 半环, semiring, 728
- 半监督分类, semi-supervised classification, 143
- 半监督聚类, semi-supervised clustering, 208
- 协同训练, co-training, 160
- 单射, injective, 489
- 单特征规则, one rule, 123
- 单边梯度采样, gradient-based one-side sampling, 300
- 卡方自动交互检测, chi-square automatic interaction detection, 122
- 卷积, convolution, 337
- 卷积核, convolution kernel, 378
- 卷积神经网络, convolutional neural network, 375

- 原型, prototype, 11
- 原型向量, prototype vector, 110
- 原始交互图, primal graph, 745
- 原始-对偶间隙, primal-dual gap, 803
- 去噪分数匹配, denoising score matching, 959
- 去噪扩散概率模型, denoising diffusion probabilistic model, 954
- 去相关批归一化, DBN, 617
- 参数共享, parameter sharing, 321, 375, 427, 640, 675, 831, 924
- 参数化 ReLU, parametric ReLU, 345
- 参数学习, parameter learning, 656, 830
- 参数绑定, weight tying, 640
- 参考类, reference class, 128
- 双向循环网络, bidirectional RNN, 464
- 双曲正切函数, hyperbolic tangent, 343
- 反向传播, backpropagation, 359
- 发射分布, emission distribution, 926
- 发现数据, discovery data, 215
- 受约束树宽, constrained treewidth, 748
- 受限玻尔兹曼机, restricted Boltzmann machine, 907
- 变分 EM, variational EM, 844
- 变分推断, variational inference, 775
- 变分消息传递, variational message passing, 782
- 变分状态估计, variational state estimation, 941
- 变分自编码器, variational autoencoder, 281, 945
- 变量消除, variable elimination, 730
- 口袋算法, Pocket algorithm, 78
- 可分解性, decomposability, 964
- 可切换归一化, SwitchableNorm, 628
- 可学习性, learnability, 369
- 可忽略性, ignorability, 847
- 可识别性, identifiability, 127
- 可达图, reachability plot, 181
- 可达距离, reachability distance, 181
- 可靠性, soundness, 688
- 合并协方差, pooled covariance, 67
- 合页损失, hinge loss, 74, 93
- 同分布泛化, in-distribution generalization, 574, 637
- 同构, isomorphic, 489
- 同步序列到序列, aligned sequence-to-sequence, 429
- 同步批归一化, synchronized BatchNorm, 619
- 后代, descendant, 660
- 后向模式, reverse mode, 365
- 后置层归一化, post-layer normalization, 523
- 后验坍塌, posterior collapse, 949
- 后验预测, posterior predictive, 851
- 后验预测检查, posterior predictive check, 797, 854
- 向量扩散映射, vector diffusion maps, 268
- 和积, sum-product, 727
- 和积消息, sum-product message, 754
- 哈密顿蒙特卡洛, Hamiltonian Monte Carlo, 815
- 哨兵词元, sentinel token, 541
- 噪声对比估计, noise-contrastive estimation, 129, 836
- 噪声注入, noise injection, 648
- 噪声点, noise point, 178
- 回代拟合, backfitting, 38
- 回声状态性质, echo state property, 438
- 回声状态网络, echo state network, 437
- 回归, regression, 15
- 回溯表, backpointer table, 740
- 回溯记录, backpointer, 756
- 因子 HMM, factorial HMM, 932
- 因子分析, factor analysis, 270, 891
- 因子图, factor graph, 655, 724
- 因子约简, factor reduction, 732
- 因果 Markov 性, causal Markov condition, 872
- 因果充分性, causal sufficiency, 872
- 因果注意力, causal attention, 520
- 团, clique, 680
- 团交图, clique intersection graph, 760
- 团势, clique potential, 762
- 团树, junction tree, 757
- 困惑度, perplexity, 258
- 围绕中心样本划分, Partitioning Around Medoids, 174
- 图, graph, 473
- 图 Lasso, graphical lasso, 869
- 图上的感受野, graph receptive field, 476
- 图傅里叶变换, graph Fourier transform, 484
- 图分离, graph separation, 687
- 图卷积, graph convolution, 483
- 图卷积网络, graph convolutional network, 486
- 图同构网络, graph isomorphism network, 489
- 图快照, graph snapshot, 494
- 图拉普拉斯矩阵, graph Laplacian, 153, 484
- 图核, graph kernel, 10
- 图注意力网络, graph attention network, 488
- 图神经网络, graph neural network, 336, 474
- 图结构语义, graph-structured semantics, 657
- 在线归一化, OnlineNorm, 620
- 均值参数, mean parameter, 777
- 均值漂移, Mean Shift, 182

- 均值漂移向量, mean shift vector, 183
- 均匀 BDe 评分, BDe uniform, 862
- 均方根归一化, root mean square normalization, 567, 621
- 基于分布估计的参数学习, Bayesian parameter learning, 831
- 基学习器, base learner, 13, 287
- 基尼不纯度, Gini impurity, 116
- 堆叠循环网络, stacked RNN, 466
- 填充掩码, padding mask, 520
- 填充边, fill-in edge, 706, 745
- 增广向量, augmented vector, 73
- 增量减错剪枝, incremental reduced error pruning, 118
- 增长率, growth rate, 417
- 复合似然, composite likelihood, 836
- 外侧膝状体, lateral geniculate nucleus, 324
- 外周神经系统, peripheral nervous system, 323
- 外场, external field, 904
- 多值偏差, multivalued attribute bias, 113
- 多元自适应回归样条, multivariate adaptive regression splines, 51
- 多关系图, multi-relational graph, 494
- 多头注意力, multi-head attention, 521
- 多层感知机, multilayer perceptron, 316
- 多查询注意力, multi-query attention, 559
- 多标签分类, multilabel classification, 355
- 多模态处理, multimodal processing, 332
- 多维循环网络, multi-dimensional RNN, 464
- 多维缩放, multidimensional scaling, 240
- 多重集, multiset, 475
- 多项式中国剩余定理, polynomial Chinese remainder theorem, 392
- 多项式朴素贝叶斯, multinomial naive Bayes, 132
- 多项式核, polynomial kernel, 8
- 多项式重采样, multinomial resampling, 820
- 大脑皮层, cerebral cortex, 324
- 大间隔最近邻, large margin nearest neighbor, 104
- 奇异值分解, singular value decomposition, 221
- Viterbi 算法, Viterbi algorithm, 915, 929
- 子图训练, subgraph training, 481
- 子节点, child, 660
- 字典学习, dictionary learning, 233
- 字符串核, string kernel, 10
- 学习与近似推断, learning and approximate inference, 657
- 学习向量量化, learning vector quantization, 110
- 学习率调度, learning rate scheduling, 602
- 安全半监督支持向量机, safe semi-supervised support vector machine, 162
- 完全数据, complete data, 160, 840
- 完全随机缺失, missing completely at random, 846
- 完备性, completeness, 688
- 完成的部分有向无环图, completed partially directed acyclic graph, 857
- 完美干预, perfect intervention, 874
- 完美映射, perfect map, 708
- 完美有向图, perfect directed acyclic graph, 706
- 完美消除序, perfect elimination ordering, 706
- 实例归一化, instance normalization, 623
- 密度可达, density-reachable, 178
- 密度相连, density-connected, 178
- 密集单元, dense unit, 194
- 密集连接, dense connection, 417, 632
- 对偶, duality, 30
- 对偶 PPCA, dual PPCA, 278
- 对偶分解, dual decomposition, 799
- 对偶问题, dual problem, 83
- 对数几率, log-odds, 125
- 对数域, log domain, 750
- 对数线性模型, log-linear model, 699
- 对比散度, contrastive divergence, 837
- 对称归一化拉普拉斯, symmetric normalized Laplacian, 484
- 对称树, symmetric tree, 302
- 对角加低秩, diagonal plus low-rank, 453
- 小批量, mini-batch, 362
- 小批量 K 均值聚类, Mini-Batch K-means, 171
- 局部 Markov 性质, local Markov property, 661, 681
- 局部切空间对齐, local tangent space alignment, 268
- 局部加权回归, locally estimated scatterplot smoothing, 42
- 局部响应归一化, local response normalization, 628
- 局部多面体, local polytope, 787
- 局部感受野, local receptive field, 375
- 局部极大点, local maximum, 595
- 局部极小点, local minimum, 595
- 局部注意力, local attention, 446
- 局部线性嵌入, locally linear embedding, 248
- 局部连接, local connectivity, 321
- 局部随机过程, local stochastic process, 656
- 层归一化, layer normalization, 460, 523, 621
- 层次 Softmax, hierarchical softmax, 129
- 层次 VAE, hierarchical VAE, 950
- 层次模型, hierarchical model, 894
- 层次特征, hierarchical feature, 326
- 层次狄利克雷过程, hierarchical Dirichlet process, 899
- 层次聚类, hierarchical clustering, 196

- 层次表示, hierarchical representation, 320
- 岭回归, ridge regression, 21
- 工作响应, working response, 35
- 布朗运动, Brownian motion, 960
- 带泄漏的 ReLU, leaky ReLU, 344
- 干预 Markov 等价类, interventional Markov equivalence class, 874
- 干预本质图, interventional essential graph, 874
- 平均单依赖估计器, averaged one-dependence estimators, 142
- 平均场近似, mean-field approximation, 779
- 平均感知机, averaged perceptron, 79
- 平均池化, average pooling, 402
- 平坦区域, flat region, 595
- 平滑, smoothing, 924
- 平滑假设, smoothness assumption, 153
- 平移不变性, translation invariance, 376
- 平移等变性, translation equivariance, 376
- 平稳分布, stationary distribution, 811, 926
- 幽灵批归一化, Ghost BatchNorm, 619
- 广义 EM, generalized EM, 844
- 广义 Gauss-Newton 矩阵, generalized Gauss-Newton matrix, 611
- 广义可加模型, generalized additive model, 37
- 广义最小二乘, generalized least squares, 19
- 广义特征值问题, generalized eigenvalue problem, 68
- 广义线性模型, generalized linear model, 33
- 广义置信传播, generalized belief propagation, 790
- 序列内注意力, intra-attention, 508
- 序列到分类, sequence classification, 429
- 序列最小优化, sequential minimal optimization, 85
- 序贯蒙特卡洛, sequential Monte Carlo, 818
- 序贯重要性采样, sequential importance sampling, 819
- 度量 MDS, metric MDS, 241
- 度量学习, metric learning, 104
- 异或, exclusive OR, 318
- 异构图, heterogeneous graph, 494
- 弦, chord, 706
- 弦化, chordal completion, 706
- 弦图, chordal graph, 706
- 弱并, weak union, 683
- 弹性网, elastic net, 21
- 强对偶, strong duality, 30
- 归一化, normalization, 615
- 归一化割, normalized cut, 188
- 归纳偏置, inductive bias, 321, 637
- 归纳学习, inductive learning, 481
- 循环卷积, circular convolution, 378
- 循环图神经网络, recurrent graph neural network, 491
- 循环神经网络, recurrent neural network, 335, 426
- 必连约束, must-link, 208
- 忠实性, faithfulness, 668, 858
- 忠实的, faithful, 668
- 快速傅里叶变换, fast Fourier transform, 395
- 快速因果推断算法, fast causal inference, 873
- Wake-Sleep 算法, wake-sleep algorithm, 845
- 恒等函数, identity function, 342
- 恒等初始化, identity initialization, 633
- 悲观错误剪枝, pessimistic error pruning, 115
- 感受野, receptive field, 326
- 感知机, perceptron, 73
- 感知机损失, perceptron loss, 74
- 成员模型, member model, 286
- 成对 Markov 性质, pairwise Markov property, 681
- 截断间隔损失, ramp loss, 88
- 截断随时间反向传播, truncated BPTT, 433
- α 扩展, α -expansion, 803
- 扩展 Kalman 滤波, extended Kalman filter, 940
- 扩散映射, diffusion map, 253
- 扩散模型, diffusion model, 954
- 批再归一化, batch renormalization, 620
- 批归一化, batch normalization, 403, 618
- 批通道归一化, BCN, 621
- 投影聚类, projected clustering, 196
- 投票感知机, voted perceptron, 78
- 折叠 Gibbs 采样, collapsed Gibbs sampling, 815
- 折外预测, out-of-fold prediction, 304, 310
- 拉普拉斯平滑, Laplace smoothing, 133
- 拉普拉斯支持向量机, Laplacian SVM, 162
- 拉普拉斯特征映射, Laplacian Eigenmaps, 250
- 拉普拉斯近似, Laplace approximation, 59, 793, 851
- 拒绝采样, rejection sampling, 807
- 拓扑序, topological order, 660
- 拟牛顿方法, quasi-Newton methods, 610
- 拥挤问题, crowding problem, 260
- 持久链, persistent chain, 837
- 指数族, exponential family, 699, 776
- 指数族 PCA, exponential family PCA, 280
- 指数移动平均, exponential moving average, 643
- 指数线性单元, exponential linear unit, 346
- 接收门加权键值网络, receptance weighted key value, 460
- 控制变量, control variate, 810

- 控制门, gate, 440
- 推断误差, inference error, 853
- 掩码, mask, 434
- 掩码自回归流, masked autoregressive flow, 952
- 掩码自编码分布估计器, masked autoencoder for distribution estimation, 886
- 提前终止, early stopping, 642
- 插件预测, plug-in prediction, 851
- 摊销推断, amortized inference, 784, 845
- 摊销误差, amortization error, 845, 948
- 支持向量, support vector, 84
- 支持向量回归, support vector regression, 29
- 支持向量机, support vector machine, 80
- 收缩映射, contraction mapping, 497
- 收集, collect, 755
- 教师强制, teacher forcing, 434, 527
- 数值微分, numerical differentiation, 364
- 数据填充, padding, 382
- 数据增强, data augmentation, 638
- 数据展开, im2col, 399
- 整数线性规划, integer linear programming, 797
- 整流线性单元, rectified linear unit, 318
- 新息, innovation, 933
- 新皮层, neocortex, 324
- 新认知机, neocognitron, 329
- 方差保持初始化, variance-preserving initialization, 632
- 旋转不唯一性, rotational non-identifiability, 893
- 旋转位置编码, rotary position embedding, 549
- 无向图, undirected graph, 679
- 无向图模型, undirected graphical model, 655, 680
- 无屏蔽碰撞结构, unshielded collider, 856
- 无迹 Kalman 滤波, unscented Kalman filter, 940
- 无迹变换, unscented transform, 940
- 早期夸大, early exaggeration, 262
- 时间切片, time slice, 922
- 时间展开, unrolling through time, 427
- 时间展开批归一化, BNNT, 620
- 时间接口, temporal interface, 924
- 时间编码, temporal coding, 583
- 时间齐次性, time homogeneity, 924
- 显式持续时间模型, explicit-duration model, 931
- 显著图, saliency map, 507
- 普通最小二乘, ordinary least squares, 15
- 替代分裂, surrogate split, 48, 118
- 替代梯度, surrogate gradient, 589
- 最可能状态序列, most probable state sequence, 924
- 最可能解释, most probable explanation, 727, 739
- 最大似然估计, maximum likelihood estimation, 126, 831
- 最大后验估计, maximum a posteriori estimation, 54, 831
- 最大方差展开, maximum variance unfolding, 268
- 最大池化, max pooling, 402
- 最大祖先图, maximal ancestral graph, 872
- 最大积, max-product, 727
- 最大积消息, max-product message, 756
- 最大边缘, max-marginal, 756
- 最小 I-map, minimal I-map, 708
- 最小填充启发式, min-fill, 747
- 最小度启发式, min-degree, 747
- 最小描述长度, minimum description length, 119, 861
- 最小权重启发式, min-weight heuristic, 748
- 最弱环节剪枝, weakest-link pruning, 117
- 最近质心分类器, nearest centroid classifier, 111
- 有向因子分解, directed factorization, 670
- 有向图, directed graph, 660
- 有向图模型, directed graphical model, 655, 660
- 有向无环图, directed acyclic graph, 660
- 有向路径, directed path, 660
- 有序 Markov 假设, ordered Markov assumption, 660
- 有序目标统计, ordered target statistic, 301
- 有效样本量, effective sample size, 796, 826
- 有限内存拟牛顿法, limited-memory BFGS, 127
- 有限混合模型, finite mixture model, 888
- 期望传播, expectation propagation, 60, 791
- 期望最大化, expectation-maximization, 137, 203, 274
- 期望最大化算法, expectation-maximization algorithm, 840
- 朴素贝叶斯, naive Bayes, 130, 882
- 权重归一化, weight normalization, 626
- 权重有效样本量, weight-based ESS, 826
- 权重标准化, weight standardization, 626
- 权重衰减, weight decay, 646
- 权重退化, weight degeneracy, 820
- 束搜索, beam search, 123
- 条件 Markov 网络, conditional Markov network, 702
- 条件互信息, conditional mutual information, 858
- 条件 VAE, conditional VAE, 950
- 条件图像生成, conditional image generation, 423
- 条件归一化, conditional normalization, 620
- 条件推断树, conditional inference tree, 53, 122
- 条件数, condition number, 597
- 条件概率表, conditional probability table, 674, 832
- 条件独立, conditional independence, 130, 654
- 条件线性高斯模型, conditional linear Gaussian model, 677

- 条件计算, conditional computation, 335
条件随机场, conditional random field, 838, 913
松弛变量, slack variable, 92
板表示法, plate notation, 894
极大团, maximal clique, 680, 759
极度随机树, extremely randomized trees, 293
查询, query, 513
查询-键归一化, QKNorm, 622
标签交换, label switching, 854, 890, 930
标签传播, label propagation, 149
标签扩散, label spreading, 161
树增强朴素贝叶斯, tree-augmented naive Bayes, 883
树宽, treewidth, 746
树核, tree kernel, 10
树状图, dendrogram, 196
树结构长短期记忆, Tree-LSTM, 465
树递归网络, recursive neural network, 336, 465
树重加权, tree-reweighted, 791, 800
校准, calibration, 764
样本贫化, sample impoverishment, 822
核 Fisher 判别, kernel Fisher discriminant, 100
核 K-means, kernel K-means, 177
核主成分分析, kernel principal component analysis, 237
核密度估计, kernel density estimation, 183
核心点, core point, 178
核心距离, core distance, 181
核感知机, kernel perceptron, 78
核技巧, kernel trick, 4
核方法, kernel method, 3
桶, bucket, 734
梯度下降, gradient descent, 601
梯度提升决策树, gradient boosting decision tree, 298
梯度提升机, gradient boosting machine, 297
梯度消失, vanishing gradients, 364, 434, 599
梯度爆炸, exploding gradients, 364, 434, 599
梯度裁剪, gradient clipping, 433, 602
概率主成分分析, probabilistic principal component analysis, 270, 891
概率图模型, probabilistic graphical model, 652
概率建模, probabilistic modeling, 12
概率推断, probabilistic inference, 655
概率校准, probability calibration, 129, 854
概率流常微分方程, probability flow ordinary differential equation, 962
概率潜在语义分析, probabilistic latent semantic analysis, 895
概率生成模型, probabilistic generative model, 944
概率电路, probabilistic circuit, 963
模块度, modularity, 192
模型容量, model capacity, 637
模型树, model tree, 51
模型类完备性, model-class completeness, 667
模型近似误差, model approximation error, 948
模糊 C 均值, Fuzzy C-Means, 176
模糊单纯集, fuzzy simplicial set, 265
次梯度, subgradient, 23
次模, submodular, 801
正 Harris 常返性, positive Harris recurrence, 812
正交初始化, orthogonal initialization, 632
正则化, regularization, 21
正则化判别分析, regularized discriminant analysis, 100
正定核, positive definite kernel, 4
正规方程, normal equations, 17
残差连接, residual connection, 414, 523, 631
比率割, RatioCut, 188
汉明距离, Hamming distance, 97, 103
池化, pooling, 329, 402
泛化, generalization, 317
注意力机制, attention mechanism, 334, 445
洗出期, washout, 437
活跃, active, 665
流形, manifold, 244
测地距离, geodesic distance, 245
测试预测, test prediction, 310
消息, message, 752
消息传递, message passing, 337, 475
液态状态机, liquid state machine, 438
深度, depth, 341
深度储备池计算, deep reservoir computing, 467
深度可分离卷积, depthwise separable convolution, 401
混合, mixing, 812
混合 PPCA, mixture of PPCA, 280
混合专家, mixture of experts, 335, 564
混合成员, mixed membership, 895
满条件分布, full conditional distribution, 813
滤波, filtering, 818, 924
滤波响应归一化, FRN, 624
漏积分发放模型, leaky integrate-and-fire model, 584
潜变量, latent variable, 12, 830, 888
潜在狄利克雷分配, latent Dirichlet allocation, 895
潜空间扩散, latent diffusion, 965
激活函数, activation function, 318
XGBoost, 298