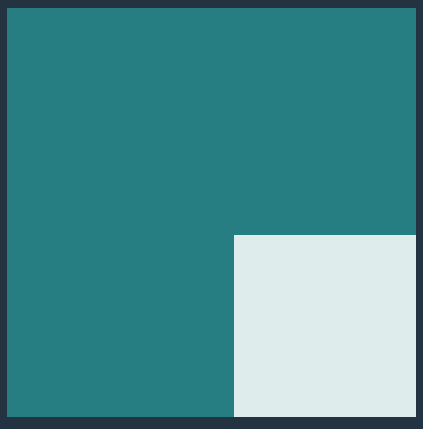
MACHINE LEARNING NOTES

机器学习笔记

卷六：系统



施晓罡

2026 年・第一版

MACHINE LEARNING NOTES

机器学习笔记

卷六：系统

施晓罡

2026 年・第一版

机器学习笔记

MACHINE LEARNING NOTES

作者：施晓罡

版本：第一版

年份：2026

Copyright © 2026 施晓罡



Licensed under the Creative Commons Attribution-NonCommercial-NoDerivatives 4.0 International License (the ”License”);

You may not use this file except in compliance with the License.

You may obtain a copy of the License at

https://creativecommons.org/licenses/by-nc-nd/4.0/

Unless required by applicable law or agreed to in writing, software distributed under the License is distributed on an ”AS IS” BASIS, WITHOUT WARRANTIES OR CONDITIONS OF ANY KIND, either express or implied. See the License for the specific language governing permissions and limitations under the License.

前言

本书目标

机器学习把数据、模型和计算连接起来，但理解一种方法，不能只记住模型名称或训练步骤。还需要知道模型能够表示什么规律，学习结论依赖哪些数据与假设，什么证据足以支持评价，以及方法进入具体应用和运行系统后会受到哪些约束。本书沿着这些联系组织内容，希望读者不仅会使用算法，也能解释一个结果为何成立、何时可信，以及怎样把它放入完整的技术过程。

本书面向已经具备基本微积分、线性代数、概率统计和编程基础，希望系统理解机器学习的读者。正文会在需要时回顾具体工具，但不以这些基础课程的完整讲解为目标。阅读后，读者应能从任务和证据出发比较模型与学习方式，并把理论条件、实验评价、应用要求和系统实现放在同一条推理链上考察。

本书内容

全书分为六卷。第一卷“数学准备”建立分析、代数、概率、离散结构与动态决策的共同语言。第二卷“基础、理论和可信性”说明学习如何发生、学习保证依赖哪些条件，以及可靠性、鲁棒性、公平性和隐私等可信要求应由什么证据支持。第三卷“模型”考察经典模型、神经网络模型和概率图模型的结构、推断与学习。第四卷“范式”转向经验和知识的获得方式，讨论交互反馈、有限标注以及任务变化下如何学习、复用和迁移知识。前四卷提供数学工具、分析依据和方法选择，后两卷把这些选择放入实际约束。第五卷“应用”围绕自然语言处理、图像处理、推荐与搜索，说明任务目标、数据形态、模型和评价方式如何相互制约。第六卷“系统”连接数据准备、训练计算、部署服务与运行维护，考察方法如何成为可持续运行的机器学习系统。这样的次序并不表示建模、应用和系统彼此割裂：应用需求决定评价口径，系统条件限制可用方法，而运行中的证据又会促使模型和学习过程重新调整。

参考资料

下面按内容列出可与本书配合阅读的教材。每本书的侧重点不同，读者可以根据正在阅读的卷和需要补充的问题选择查阅，不必按列表顺序通读。

综合与基础

- Mitchell 的 *Machine Learning* 从概念学习、归纳偏置和代表性算法出发，适合查阅机器学习的基本问题和早期统一框架。
- Bishop 的 *Pattern Recognition and Machine Learning* 将概率建模、决策理论、核方法和近似推断联系起来，适合查阅概率视角下的模型与推断方法。
- 周志华的《机器学习》覆盖常用模型、学习理论和实践问题，适合按任务比较方法的基本假设与用途。
- 李航的《统计学习方法（第 2 版）》以统计机器学习为定位，适合按模型查阅定义、算法和数学推导。
- Deisenroth、Faisal 和 Ong 的 *Mathematics for Machine Learning* 适合补充线性代数、解析几何、矩阵微积分、概率与优化等数学工具。

统计学习与学习理论

- Hastie、Tibshirani 和 Friedman 的 *The Elements of Statistical Learning* 适合查阅回归、分类、正则化、模型选择和统计学习方法。
- Shalev-Shwartz 和 Ben-David 的 *Understanding Machine Learning: From Theory to Algorithms* 适合查阅 PAC 框架、复杂度、泛化界与优化基础。
- Mohri、Rostamizadeh 和 Talwalkar 的 *Foundations of Machine Learning* 适合查阅学习界、核方法、在线学习及其理论保证。
- James、Witten、Hastie 和 Tibshirani 的 *An Introduction to Statistical Learning* 适合结合 R 实例理解回归、分类、重采样、正则化、树模型和无监督学习。

概率模型与图模型

- Murphy 的 *Machine Learning: A Probabilistic Perspective* 以概率视角组织监督学习、无监督学习、潜变量模型和图模型，适合查阅模型间的联系。

- Murphy 的 *Probabilistic Machine Learning: An Introduction* 适合查阅现代概率机器学习的统一记号、计算方法和模型实例。
- Murphy 的 *Probabilistic Machine Learning: Advanced Topics* 适合查阅深度生成模型、状态空间模型、贝叶斯优化和相关近似推断方法。
- Koller 和 Friedman 的 *Probabilistic Graphical Models: Principles and Techniques* 适合系统查阅图模型的表示、精确与近似推断以及参数和结构学习。
- Rasmussen 和 Williams 的 *Gaussian Processes for Machine Learning* 适合深入理解高斯过程、核函数、贝叶斯预测和超参数学习。

神经网络与深度学习

- Goodfellow、Bengio 和 Courville 的 *Deep Learning* 适合查阅神经网络表示、优化、正则化和深度生成模型。
- Bishop 和 Bishop 的 *Deep Learning: Foundations and Concepts* 从概率基础连接常用架构与训练方法，适合查阅相应概念和推导。
- 邱锡鹏的《神经网络与深度学习》适合查阅前馈、卷积、循环、注意力网络及其训练方法。
- Zhang、Lipton、李沐和 Smola 的 *Dive into Deep Learning* 适合结合可运行代码理解神经网络的实现、训练与调参过程。
- Géron 的 *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow* 适合查阅从数据准备、模型训练到评估和部署的实践流程。

强化学习

- Sutton 和 Barto 的 *Reinforcement Learning: An Introduction* 适合查阅马尔可夫决策过程、价值方法、策略方法与函数逼近。
- Szepesvári 的 *Algorithms for Reinforcement Learning* 适合查阅动态规划、Monte Carlo、时序差分和函数逼近算法的数学形式与分析。

应用与系统

- Manning、Raghavan 和 Schütze 的 *Introduction to Information Retrieval* 适合查阅文本表示、索引、检索模型和评价方法。
- Huyen 的 *Designing Machine Learning Systems* 从数据、训练、部署与监控讨论机器学习系统设计，适合查阅模型进入生产环境后的工程约束。

- Jurafsky 和 Martin 的 *Speech and Language Processing* 适合查阅自然语言与语音处理中的语言模型、序列标注、句法分析和语音识别。
- Szeliski 的 *Computer Vision: Algorithms and Applications* 适合查阅成像、特征、几何、识别与图像合成方法。
- Aggarwal 的 *Recommender Systems: The Textbook* 适合查阅协同过滤、基于内容的推荐、矩阵分解和推荐评价。
- Kleppmann 和 Riccomini 的 *Designing Data-Intensive Applications* 适合查阅存储、复制、分区、事务以及流式与批量处理的系统取舍。

上述教材的完整出版信息列于卷末参考文献。

数学符号

下表汇总全书反复使用的记号。各章若赋予符号更具体的含义，会在首次使用时另行说明。

对象与线性代数

对象	常用记号	含义
数集	$\mathbb{N}$, $\mathbb{Z}$, $\mathbb{R}$, $\mathbb{R}_+$	自然数集、整数集、实数集和非负实数集
集合与关系	$x \in A$, $A \subseteq B$, $A \cup B$, $A \cap B$, $\lvert A \rvert$	元素属于集合、子集、并集、交集和有限集合的基数
标量	a, x, $\lambda \in \mathbb{R}$	单个数值；小写斜体字母通常表示标量
向量	$\boldsymbol{x}$, $\boldsymbol{w} \in \mathbb{R}^d$	d 维向量；加粗小写字母表示向量
矩阵	$\boldsymbol{A} \in \mathbb{R}^{m \times n}$, $\boldsymbol{A}_{i,j}$	m 行 n 列矩阵及其第 i 行、第 j 列元素
数据与样本	$\mathcal{D} = \{(\boldsymbol{x}_i, y_i)\}_{i=1}^n$	含 n 个输入标签对的数据集；下标 i 表示样本索引
切片与迭代	$\boldsymbol{A}_{i,:}$, $\boldsymbol{A}_{:,j}$, $\boldsymbol{w}^{(t)}$	矩阵的第 i 行、第 j 列，以及第 t 次迭代的向量
Kronecker delta	$\delta_{i,j}$	当 $i = j$ 时取 1，否则取 0
矩阵变换	$\boldsymbol{A}^\top$, $\boldsymbol{A}^{-1}$, $\boldsymbol{A}^\dagger$, $\boldsymbol{I}_d$, $\operatorname{tr}(\boldsymbol{A})$	转置、逆、伪逆、d 阶单位矩阵和矩阵的迹
代数运算	$\langle \boldsymbol{x}, \boldsymbol{y} \rangle$, $\boldsymbol{x}^\top \boldsymbol{A} \boldsymbol{x}$, $\sum_i a_i$, $\prod_i a_i$	内积、二次型、求和与连乘
函数与模型	$f : \mathcal{X} \to \mathcal{Y}$, $h_{\boldsymbol{w}}(\boldsymbol{x})$	从输入空间到输出空间的函数，以及参数为 $\boldsymbol{w}$ 的模型
范数与距离	$\lVert \boldsymbol{x} \rVert_p$, $d(\boldsymbol{x}, \boldsymbol{y})$	p 范数与两对象之间的距离；具体定义由上下文给出

微积分与优化

对象	常用记号	含义
导数与梯度	$\dfrac{\mathrm{d}f}{\mathrm{d}x}$, $\nabla_{\boldsymbol{w}} L(\boldsymbol{w})$	一元导数，以及标量值函数对参数向量的梯度
Jacobian 与 Hessian	$\nabla_{\boldsymbol{x}} \boldsymbol{f}$, $\nabla_{\boldsymbol{x}}^2 f$	向量值函数的一阶偏导矩阵，以及标量值函数的二阶偏导矩阵
渐近阶	$f(n) = \mathcal{O}(g(n))$	函数增长率的渐近上界
最优化	$\min_{\boldsymbol{w}} L(\boldsymbol{w})$, $\boldsymbol{w}^* \in \arg\min_{\boldsymbol{w}} L(\boldsymbol{w})$	最小目标值与取得最小值的参数；最大化使用 max 和 arg max

概率与信息论

对象	常用记号	含义
随机变量与实现	$X,\ \boldsymbol{X},\ x,\ \boldsymbol{x},\ p_X(x)$	随机标量、随机向量及其实现值；p_X 表示概率质量或密度函数
联合与条件概率	$p(x,y),\ p(x \mid y)$	随机变量实现值的联合概率与条件概率
边缘概率	$p(x)=\sum_y p(x,y),\ p(x)=\int p(x,y)\,\mathrm{d}y$	分别对离散变量求和或对连续变量积分得到的边缘概率
独立性与抽样	$X \perp Y,\ X \perp Y \mid Z,\ X_i \overset{\text{i.i.d.}}{\sim} p$	独立、给定 Z 条件独立，以及独立同分布抽样
矩与相关性	$\mathbb{E}[X],\ \mathrm{Var}(X),\ \mathrm{Cov}(X,Y)$	期望、方差和协方差
常用分布	$\mathrm{Bernoulli}(p),\ \mathrm{Cat}(\boldsymbol{\pi}),\ \mathcal{N}(\boldsymbol{\mu},\boldsymbol{\Sigma})$	伯努利分布、类别分布和多元高斯分布
事件指示函数	$\mathbb{I}\{A\}$	事件 A 成立时取 1，否则取 0
信息量	$H(p),\ H(p,q),\ \mathrm{KL}(p\|\|q)$	熵、交叉熵和分布 p 相对于 q 的 KL 散度
概率正比关系	$p(\boldsymbol{x}) \propto q(\boldsymbol{x})$	忽略归一化常数时的概率正比关系

目录

第一部分 机器学习系统 1

参考文献 2

索引 4

第一部分

机器学习系统

Machine Learning Systems

参考文献

C. C. Aggarwal, *Recommender Systems*, Springer, 2016.

C. M. Bishop, *Pattern Recognition and Machine Learning*, Springer, 2006, 1st ed.

C. M. Bishop, H. Bishop, *Deep Learning: Foundations and Concepts*, Springer, 2024.

M. P. Deisenroth, A. A. Faisal, C. S. Ong, *Mathematics for Machine Learning*, Cambridge University Press, 2020.

A. Géron, *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow*, O'Reilly Media, 2022, 3rd ed.

I. Goodfellow, Y. Bengio, A. Courville, *Deep Learning*, MIT Press, 2016.

T. Hastie, R. Tibshirani, J. Friedman, *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*, Springer, 2009, 2nd ed.

C. Huyen, *Designing Machine Learning Systems*, O'Reilly Media, 2022.

G. James, D. Witten, T. Hastie, R. Tibshirani, *An Introduction to Statistical Learning*, Springer, 2021, 2nd ed.

D. Jurafsky, J. H. Martin, *Speech and Language Processing*, Prentice Hall, 2009, 2nd ed.

M. Kleppmann, C. Riccomini, *Designing Data-Intensive Applications*, O'Reilly Media, 2026, 2nd ed.

D. Koller, N. Friedman, *Probabilistic Graphical Models: Principles and Techniques*, MIT Press, 2009.

C. D. Manning, P. Raghavan, H. Schütze, *Introduction to Information Retrieval*, Cambridge University Press, 2008.

T. M. Mitchell, *Machine Learning*, McGraw-Hill, 1997, 1st ed.

M. Mohri, A. Rostamizadeh, A. Talwalkar, *Foundations of Machine Learning*, The MIT Press, 2018, 2nd ed.

K. P. Murphy, *Machine Learning: A Probabilistic Perspective*, MIT Press, 2012.

K. P. Murphy, *Probabilistic Machine Learning*, The MIT Press, 2023.

K. P. Murphy, *Probabilistic Machine Learning: An Introduction*, MIT Press, 2022.

C. E. Rasmussen, C. K. I. Williams, *Gaussian Processes for Machine Learning*, MIT Press, 2006.

S. Shalev-Shwartz, S. Ben-David, *Understanding Machine Learning: From Theory to Algorithms*, Cambridge University Press, 2014, 1st ed.

R. S. Sutton, A. G. Barto, *Reinforcement Learning: An Introduction*, MIT Press, 2018, 2nd ed.

R. Szeliski, *Computer Vision*, Springer, 2022, 2nd ed.

C. Szepesvári, *Algorithms for Reinforcement Learning*, Morgan & Claypool Publishers, 2010.

A. Zhang, Z. C. Lipton, M. Li, A. J. Smola, *Dive into Deep Learning*, Cambridge University Press, 2023.

周志华, 机器学习, 清华大学出版社, 2016, 1st ed.

李航, 统计学习方法, 清华大学出版社, 2019, 2nd ed.

邱锡鹏, 神经网络与深度学习, 机械工业出版社, 2020.

索引